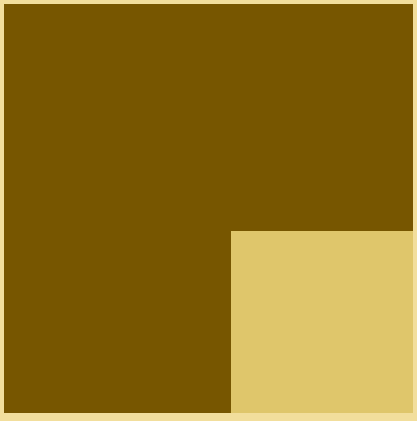
MATHEMATICS NOTES

数学笔记

卷二 · 向量、矩阵与多元微积分



施晓罡

2026 年 · 第一版

MATHEMATICS NOTES

数学笔记

卷二 · 向量、矩阵与多元微积分

施晓罡

2026 年 · 第一版

数学笔记

MATHEMATICS NOTES

作者：施晓罡

版本：第一版

年份：2026

Copyright © 2026 施晓罡

Licensed under the Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International License (the ”License”);

You may not use this file except in compliance with the License.

You may obtain a copy of the License at

https://creativecommons.org/licenses/by-nc-nd/4.0/

Unless required by applicable law or agreed to in writing, software distributed under the License is distributed on an ”AS IS” BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied. See the License for the specific language governing permissions and limitations under the License.

前言

本书目标

给定一个对象，我们怎样描述它的结构，判断它具有哪些性质，并据此进行计算？集合、函数、向量与图提供不同的描述方式；极限、测度与概率使这些描述能够处理逼近、连续变化与随机性；优化、微分方程和控制则进一步研究解怎样求得、状态怎样演化，以及行动怎样影响结果。本书围绕这些问题整理数学概念、推导与计算方法。

这份笔记从《机器学习笔记》的数学部分独立出来，供需要系统梳理相关数学工具的读者阅读。各章在具体对象和问题中引入定义，说明结论依赖的条件，并通过证明、算例和反例检查其适用范围。阅读时可以沿正文顺序建立基础，也可以从当前问题出发查阅相应章节，再补充所需的前置内容。

内容与阅读

全书按十卷组织。卷一《集合与一元微积分》建立集合、关系、映射与计数的语言，再研究实数上函数的极限、微分与积分；卷二《向量、矩阵与多元微积分》研究线性空间、谱分析、线性方程的求解与逼近，以及多元函数的微分与积分；卷三《图》研究图的结构与遍历、图上的组合优化、集合函数与子集选择，以及图上的动态规划。

此后各卷依次讨论度量、测度、函数空间与流形，优化，微分方程，概率，推断与因果识别，状态的演进与观测，以及决策、控制与博弈中的策略。目前已完成前三卷，其余各卷仍在整理；正文提到这些卷时，按全书计划的卷章位置给出可查阅之处。各卷独立构建，章节之间按需引用。

正文使用其他数学卷的结论时，会在当前问题中交代所需关系与条件，再给出可查阅的位置。少量机器学习应用作为延伸阅读，链接指向《机器学习笔记》的固定版本；本书的数学正文与编译过程独立维护。

数学符号

下表汇总全书反复使用的记号。各章若赋予符号更具体的含义，会在首次使用时另行说明。

对象与线性代数

对象	常用记号	含义
数集	$\mathbb{N}$, $\mathbb{Z}$, $\mathbb{R}$, $\mathbb{R}_+$	自然数集、整数集、实数集和非负实数集
集合与关系	$x \in A$, $A \subseteq B$, $A \cup B$, $A \cap B$, $\lvert A \rvert$	元素属于集合、子集、并集、交集和有限集合的基数
标量	a, x, $\lambda \in \mathbb{R}$	单个数值；小写斜体字母通常表示标量
向量	$\boldsymbol{x}$, $\boldsymbol{w} \in \mathbb{R}^d$	d 维向量；加粗小写字母表示向量
矩阵	$\boldsymbol{A} \in \mathbb{R}^{m \times n}$, $\boldsymbol{A}_{i,j}$	m 行 n 列矩阵及其第 i 行、第 j 列元素
数据与样本	$\mathcal{D} = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^n$	含 n 个输入标签对的数据集；下标 i 表示样本索引
切片与迭代	$\boldsymbol{A}_{i,:}$, $\boldsymbol{A}_{:,j}$, $\boldsymbol{w}^{(t)}$	矩阵的第 i 行、第 j 列，以及第 t 次迭代的向量
Kronecker delta	$\delta_{i,j}$	当 $i = j$ 时取 1，否则取 0
矩阵变换	$\boldsymbol{A}^\top$, $\boldsymbol{A}^{-1}$, $\boldsymbol{A}^\dagger$, $\boldsymbol{I}_d$, $\operatorname{tr}(\boldsymbol{A})$	转置、逆、伪逆、d 阶单位矩阵和矩阵的迹
代数运算	$\langle \boldsymbol{x}, \boldsymbol{y} \rangle$, $\boldsymbol{x}^\top \boldsymbol{A} \boldsymbol{x}$, $\sum_i a_i$, $\prod_i a_i$	内积、二次型、求和与连乘
函数与模型	$f : \mathcal{X} \to \mathcal{Y}$, $h_{\boldsymbol{w}}(\boldsymbol{x})$	从输入空间到输出空间的函数，以及参数为 $\boldsymbol{w}$ 的模型
范数与距离	$\lVert \boldsymbol{x} \rVert_p$, $d(\boldsymbol{x}, \boldsymbol{y})$	p 范数与两对象之间的距离；具体定义由上下文给出

微积分与优化

对象	常用记号	含义
导数与梯度	$\dfrac{\mathrm{d}f}{\mathrm{d}x}$, $\nabla_{\boldsymbol{w}} L(\boldsymbol{w})$	一元导数，以及标量值函数对参数向量的梯度
Jacobian 与 Hessian	$\nabla_{\boldsymbol{x}} \boldsymbol{f}$, $\nabla_{\boldsymbol{x}}^2 f$	向量值函数的一阶偏导矩阵，以及标量值函数的二阶偏导矩阵
渐近阶	$f(n) = \mathcal{O}(g(n))$	函数增长率的渐近上界
最优化	$\min_{\boldsymbol{w}} L(\boldsymbol{w})$, $\boldsymbol{w}^* \in \arg\min_{\boldsymbol{w}} L(\boldsymbol{w})$	最小目标值与取得最小值的参数；最大化使用 max 和 arg max

概率与信息论

对象	常用记号	含义
随机变量与实现	$X,\ \boldsymbol{X},\ x,\ \boldsymbol{x},\ p_X(x)$	随机标量、随机向量及其实现值；p_X 表示概率质量或密度函数
联合与条件概率	$p(x,y),\ p(x \mid y)$	随机变量实现值的联合概率与条件概率
边缘概率	$p(x)=\sum_y p(x,y),\ p(x)=\int p(x,y)\,\mathrm{d}y$	分别对离散变量求和或对连续变量积分得到的边缘概率
独立性与抽样	$X \perp Y,\ X \perp Y \mid Z,\ X_i \overset{\text{i.i.d.}}{\sim} p$	独立、给定 Z 条件独立，以及独立同分布抽样
矩与相关性	$\mathbb{E}[X],\ \mathrm{Var}(X),\ \mathrm{Cov}(X,Y)$	期望、方差和协方差
常用分布	$\mathrm{Bernoulli}(p),\ \mathrm{Cat}(\boldsymbol{\pi}),\ \mathcal{N}(\boldsymbol{\mu},\boldsymbol{\Sigma})$	伯努利分布、类别分布和多元高斯分布
事件指示函数	$\mathbb{I}\{A\}$	事件 A 成立时取 1，否则取 0
信息量	$H(p),\ H(p,q),\ \mathrm{KL}(p\|\|q)$	熵、交叉熵和分布 p 相对于 q 的 KL 散度
概率正比关系	$p(\boldsymbol{x}) \propto q(\boldsymbol{x})$	忽略归一化常数时的概率正比关系

目录

第一部分 向量与线性空间 1

第 1 章 向量、矩阵与张量的运算 3

1.1 向量 4

1.2 矩阵 11

1.3 行列式、迹与元素内积 33

1.4 张量 44

1.5 本章小结 57

第 2 章 线性空间、映射与坐标 59

2.1 线性空间与子空间 59

2.2 基、维数与坐标 66

2.3 线性与多线性映射 78

2.4 对偶空间 99

2.5 本章小结 103

第 3 章 赋范空间与内积空间 105

3.1 范数与距离 106

3.2 收敛、极限与连续性 111

3.3 有限维赋范空间的性质 124

3.4 内积空间 137

3.5 正交与投影 153

3.6 线性泛函的内积表示与伴随 166

3.7 本章小结 171

第二部分 谱分析 173

第 4 章 特征值与谱分解 175
4.1 特征值与特征向量 175
4.2 对角化 185
4.3 正交对角化 193
4.4 一般方阵的 Schur 形 200
4.5 本章小结 204

第 5 章 奇异值分解 206
5.1 输入与输出的正交坐标 206
5.2 奇异值分解的构造 207
5.3 奇异值与矩阵范数 212
5.4 分解的核验与几何解释 214
5.5 本章小结 216

第 6 章 极分解 218
6.1 伸缩与正交转向的分离 218
6.2 伸缩因子的构造 219
6.3 正交因子与左右极分解 221
6.4 奇异与矩形矩阵的极分解 224
6.5 矩阵函数的谱表示 228
6.6 本章小结 232

第 7 章 条件数与谱扰动 233
7.1 线性作用的误差放大与条件数 233
7.2 谱与奇异值的扰动 241
7.3 本章小结 258

第 8 章 线性递推的收敛与稳定性 260
8.1 递推解的表示 260
8.2 初值影响的衰减 262
8.3 固定输入下的平衡与收敛 268
8.4 收敛速度与短期放大 272
8.5 误差传播与累积 276
8.6 本章小结 279

第三部分 线性方程与优化 281

第 9 章	线性方程与最小二乘的选解	283
9.1	方程的相容性与解集	284
9.2	最小二乘解	286
9.3	最小范数解	289
9.4	伪逆与解的表示	290
9.5	加权最小二乘	293
9.6	齐次最小二乘	294
9.7	解的检验条件	296
9.8	本章小结	296
第 10 章	直接求解方法	298
10.1	LU 分解	299
10.2	Cholesky 分解	305
10.3	分块 LDL 分解	309
10.4	分块消元	312
10.5	低秩更新下的求解	316
10.6	正规方程法	319
10.7	QR 求解	322
10.8	SVD 求解	331
10.9	方法选择与结果检验	337
10.10	本章小结	338
第 11 章	定常迭代法	340
11.1	矩阵分裂与定常迭代	340
11.2	Richardson 迭代	344
11.3	Jacobi 迭代	346
11.4	Gauss–Seidel 迭代	348
11.5	SOR 迭代	351
11.6	SSOR 迭代	354
11.7	收敛检验与停止准则	357
11.8	本章小结	358
第 12 章	Krylov 子空间法	359
12.1	Krylov 子空间	360
12.2	共轭梯度法	361
12.3	Arnoldi 正交化	365

12.4 广义最小残差法 368
12.5 最小残差法 372
12.6 双共轭梯度法 376
12.7 稳定化双共轭梯度法 379
12.8 Golub–Kahan 双对角化 382
12.9 LSQR 算法 386
12.10 LSMR 算法 392
12.11 预条件 396
12.12 收敛检验与停止准则 401
12.13 本章小结 402

第 13 章 行列投影迭代法 404
13.1 Kaczmarz 算法 404
13.2 扩展 Kaczmarz 算法 409
13.3 结果检验与停止准则 412
13.4 本章小结 413

第 14 章 求解误差、正则化与方法选择 414
14.1 解的误差与敏感性 415
14.2 正则化方法 422
14.3 求解方法的比较与选择 430
14.4 本章小结 435

第 15 章 矩阵逼近 437
15.1 矩阵逼近问题 438
15.2 秩一逼近 439
15.3 秩 k 逼近 444
15.4 加权逼近与广义 Rayleigh 商 454
15.5 正交约束下的矩阵逼近 462
15.6 逼近结果的检验 468
15.7 本章小结 469

第 16 章 矩阵方程 471
16.1 Sylvester 方程 471
16.2 Lyapunov 方程 480
16.3 本章小结 490

第四部分 多元微积分 493

第 17 章 多元函数微分 495

17.1 多元函数与场 496

17.2 多元标量函数的一阶微分 498

17.3 多元向量值函数的微分 515

17.4 高阶微分与极值判别 524

17.5 本章小结 535

第 18 章 矩阵函数的微分 536

18.1 矩阵微分与梯度 536

18.2 基本矩阵运算的微分 538

18.3 求逆的微分 540

18.4 行列式的微分 542

18.5 对数行列式的微分 543

18.6 本章小结 544

第 19 章 隐函数与反函数 545

19.1 隐函数的存在与微分 545

19.2 反函数的局部存在与微分 550

19.3 本章小结 552

第 20 章 微分与扰动分析 554

20.1 一般映射的扰动分析 554

20.2 矩阵运算的扰动分析 558

20.3 特征值与特征向量的微分 565

20.4 本章小结 569

第 21 章 区域积分 570

21.1 区域积分的定义与性质 570

21.2 累次积分 574

21.3 区域积分的换元 576

21.4 参数积分 579

21.5 本章小结 580

第 22 章 路径积分 582

22.1 参数路径与弧长 582

22.2 第一类路径积分 586
22.3 第二类路径积分 590
22.4 路径无关与势函数 595
22.5 本章小结 602

第 23 章 曲面积分 603
23.1 参数曲面与面积元 603
23.2 第一类曲面积分 610
23.3 第二类曲面积分 613
23.4 本章小结 620

第 24 章 积分定理 622
24.1 局部微分算子 622
24.2 区域与边界的积分关系 629
24.3 本章小结 644

参考文献 646

索引 647

第一部分

向量与线性空间

Vectors and Linear Spaces

阅读指引

许多问题需要同时记录多个数，并用一组输入计算一组输出。本部分研究怎样表示这样的线性对象、怎样对它们实施运算，以及怎样在它们所在的空间中度量大小、接近与垂直。所用的只是卷一的实数与复数、映射与等价关系、有限求和，以及一元分析中的极限、确界与最值定理。

第 1章“向量、矩阵与张量的运算”把数据记成数组，按定位一个数所需的索引个数，依次建立向量、矩阵与多轴数组的运算。每种运算都核对输入的形状条件、输出的形状和运算规则；行列式、迹与 Frobenius 内积把矩阵变成一个数，张量积与缩约则统一处理多重索引。

第 2章“线性空间、映射与坐标”把数组本身与它记录的对象分开。线性空间规定哪些对象可以作线性组合，基与坐标把对象记成一列数，线性映射在两端的基下记成矩阵，对偶空间则研究把对象读成一个数的规则。换基改变坐标与矩阵，不改变对象和映射；核、像、秩等量与基的选择无关。

第 3章“赋范空间与内积空间”给线性空间补上度量结构。范数规定大小，由此定义收敛、极限与连续，并在有限维中证明范数等价与完备性；内积再规定夹角与正交，由此得到正交分解、标准正交基、正交投影与伴随。

阅读时要注意区分三组东西。第一，数组与它记录的对象：同一个向量或映射在不同基下有不同的坐标和矩阵。第二，几种不同的“乘积”：矩阵乘法汇总公共索引，逐项乘积不求和，张量积保留全部索引。第三，只依赖线性运算的结论与依赖范数或内积的结论：线性无关、维数与秩不需要度量，误差大小、夹角与最近点则随所选范数或内积改变。本部分建立的运算、坐标与几何，是后面谱分析、线性方程和多元微积分共同使用的语言。

第 1 章

向量、矩阵与张量的运算

数据常常不是一个数，而是一组数。一组观测的输出可以竖排成一列，一批样本的特征可以排成一张表，一批图像还要加上通道和像素位置，排成带多个索引的数组。这三类数组的区别不在于数的多少，而在于定位其中一个数需要几个索引：向量需要一个，矩阵需要两个，张量需要更多。

处理这些数组，先要会算。对一列数，要能把几列合成一列，把两列配成一个数，并衡量一列误差有多大。对一张表，要能一次算出许多组加权和，把接连进行的两次计算合成一次，撤销一次计算或把它重复多次，还要知道一张方阵把面积放大了多少倍。对多轴数组，要能改变它的排列，把几个数组组合起来，或沿指定的轴汇总。

本章按定位一个数所需的索引个数由少到多展开。第 1.1节建立向量的线性组合，并用坐标内积、长度和距离把向量之间的配对、大小与差异变成一个数。第 1.2节由“接连进行两次加权求和”得到矩阵乘法，再用乘法表达可以撤销的行变换、撤销一次乘法的逆矩阵，以及记录反复作用的矩阵的幂。

第 1.3节讨论把矩阵变成一个数的三种运算：行列式回答方阵把有向体积放大多少倍，迹只累加主对角元素，Frobenius 内积把两个同形矩阵的全部元素配对。第 1.4节处理多轴数组，并把前面的运算统一看成对索引的重排、组合和缩约。对每种运算，我们都核对三件事：输入须满足什么形状条件，输出是什么形状，满足哪些运算规则。

本章只在有限维实数组的层面讨论这些运算。所用的只是实数的四则运算、绝对值与平方根，以及有限个数相加时可以交换次序、重新分组的规则；这些内容可参考卷一第 4 章“实数、复数与函数”。一组数记录的是什么对象、一张矩阵怎样记录一个线性映射，是第 2章的问题；内积与范数的一般性质，以及一般空间中的长度、夹角与正交，在第 3章建立。

1.1　向量

几次观测的输入是一串数，输出也是一串数；预测减去观测，又得到一串误差。按固定次序排列的一串实数称为向量。本节先规定向量的写法，再定义三类运算：加法与数乘把几个向量合成一个向量，内积把两个向量配成一个数，长度和范数用一个数衡量向量的大小。

1.1.1　向量的表示

用向量记录数据，要先说清这串数怎样排列、每个位置记录什么，以及两个向量何时相同。

坐标向量　$\mathbb{R}^d$ 是全部有序 d 元实数组的集合。把其中一个元素的 d 个实数按原有次序竖排成一列，得到实坐标向量（real coordinate vector）：

$$\boldsymbol{u} = \begin{pmatrix} u_1 \\ \vdots \\ u_d \end{pmatrix} \in \mathbb{R}^d,$$

其中 u_j 是第 j 个坐标，d 是维数。向量中的一个数只需一个索引 j 就能定位。

列向量与行向量　本书默认使用列向量。同样的数横排成一行，称为行向量。上标 T 表示**转置**（transpose），它把行向量改写成列向量，也把列向量改写成行向量。因此 $(u_1, \dots, u_d)^{\mathsf{T}}$ 就是上面的列向量，正文常用这种写法节省篇幅。

用向量记录数据时，每个位置的含义要事先固定。例如三次观测的（输入，输出）依次为 $(1,0)$、$(2,4)$、$(3,6)$。把输入和输出分别排成向量，得到

$$\boldsymbol{x} = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \qquad \boldsymbol{y} = \begin{pmatrix} 0 \\ 4 \\ 6 \end{pmatrix}.$$

$\boldsymbol{x}$ 记录输入，$\boldsymbol{y}$ 记录输出，两个向量的第 i 个位置都对应第 i 次观测。位置的含义一致，后面才能把两个向量逐位置相加或相乘。

相等　两个向量相等，是指维数相同且对应坐标分别相等。次序是向量的一部分：$(1,2)^{\mathsf{T}}$ 与 $(2,1)^{\mathsf{T}}$ 含有同样的两个数，第一个坐标却不同，所以两者不相等。

零向量　所有坐标都为零的向量称为零向量，记作 $\mathbf{0}$。

标准坐标向量 第 j 个坐标为 1、其余坐标为 0 的向量记作 $\boldsymbol{e}_j$。$\boldsymbol{e}_1, \dots, \boldsymbol{e}_d$ 称为 $\mathbb{R}^d$ 的标准坐标向量，每个 $\boldsymbol{e}_j$ 只“点亮”第 j 个位置。例如在 $\mathbb{R}^3$ 中，$\boldsymbol{e}_2 = (0,1,0)^{\top}$。

1.1.2 加法、数乘与线性组合

两个模型各给出一列预测，取平均要用到加法和数乘；把预测和观测相减，得到误差。本小节定义这两种运算及由它们组成的线性组合，再整理它们满足的规则。

1.1.2.1 加法与数乘

同维向量按对应坐标相加减。实数 c 与向量的数乘（scalar multiplication）把每个坐标都乘以 c。对 $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^d$ 与 $c \in \mathbb{R}$，对每个 $j = 1, \dots, d$，

$$
\begin{aligned}
(\boldsymbol{x} + \boldsymbol{y})_j &= x_j + y_j, \\
(\boldsymbol{x} - \boldsymbol{y})_j &= x_j - y_j, \\
(c\boldsymbol{x})_j &= c x_j .
\end{aligned}
$$

特别地，$0\boldsymbol{x} = \boldsymbol{0}$；$-\boldsymbol{x} = (-1)\boldsymbol{x}$ 称为 $\boldsymbol{x}$ 的相反向量。结果的第 j 个坐标只由输入的第 j 个坐标决定，不同位置的数互不影响，结果仍是 d 维向量。

下面逐坐标计算一组二维向量的加法、减法与数乘。

示例 1.1　向量的加法、减法与数乘 取 $\boldsymbol{x} = (1,2)^{\top}$，$\boldsymbol{y} = (3,-1)^{\top}$，$\boldsymbol{z} = (1,-3)^{\top}$ 与 $c = 2$。按定义，第一个坐标只和第一个坐标运算，第二个坐标只和第二个坐标运算：

$$
\begin{aligned}
\boldsymbol{x} + \boldsymbol{y} &= \begin{pmatrix} 1+3 \\ 2+(-1) \end{pmatrix} = \begin{pmatrix} 4 \\ 1 \end{pmatrix}, \\
\boldsymbol{x} - \boldsymbol{y} &= \begin{pmatrix} 1-3 \\ 2-(-1) \end{pmatrix} = \begin{pmatrix} -2 \\ 3 \end{pmatrix}, \\
c\boldsymbol{z} &= \begin{pmatrix} 2 \cdot 1 \\ 2 \cdot (-3) \end{pmatrix} = \begin{pmatrix} 2 \\ -6 \end{pmatrix}.
\end{aligned}
$$

三个结果仍是二维向量。例如 $\boldsymbol{x}+\boldsymbol{y}$ 的第二个坐标 1 只来自 $\boldsymbol{x}$ 与 $\boldsymbol{y}$ 的第二个坐标 2 和 -1，与第一个坐标的取值无关。

两个向量相加，要求维数相同，还要求对应位置的含义相同。维数不同时，坐标无法逐位置配对，加法没有定义。维数相同而位置含义不同时，逐坐标相加仍能算出数，但结果没有意义。

1.1.2.2　线性组合

把加法和数乘结合起来：若干同维向量分别乘以系数后相加，得到

$$c_1\boldsymbol{v}_1 + c_2\boldsymbol{v}_2 + \cdots + c_k\boldsymbol{v}_k = \sum_{j=1}^{k} c_j\boldsymbol{v}_j,$$

称为 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_k$ 的一个**线性组合**（linear combination），$c_1, \dots, c_k$ 称为系数。

结果的第 i 个坐标是 $\sum_j c_j (\boldsymbol{v}_j)_i$，即各向量在第 i 个位置上的坐标按同一组系数加权求和。系数可以是任意实数，不要求非负，也不要求和为 1。

用线性组合可以一次写出全部预测误差。下面回到前面的三次观测。

示例 1.2　残差向量是线性组合　输入与输出仍是 $\boldsymbol{x} = (1,2,3)^{\top}$ 与 $\boldsymbol{y} = (0,4,6)^{\top}$。若用输入的 w 倍预测输出，三次预测排在一起就是数乘 $w\boldsymbol{x}$。再逐位置减去观测，得到残差向量（residual vector）

$$\boldsymbol{r} = w\boldsymbol{x} - \boldsymbol{y} = w\boldsymbol{x} + (-1)\boldsymbol{y},$$

它是 $\boldsymbol{x}, \boldsymbol{y}$ 以 w 和 -1 为系数的线性组合。例如取 $w = 1$，

$$\boldsymbol{r} = \begin{pmatrix} 1-0 \\ 2-4 \\ 3-6 \end{pmatrix} = \begin{pmatrix} 1 \\ -2 \\ -3 \end{pmatrix}.$$

$\boldsymbol{r}$ 的第 i 个坐标正是第 i 次观测的预测误差。三个误差不必逐次另算，一个线性组合就把它们同时写了出来。

下一个例子将贯穿线性空间各章。它用线性组合说明，两个特征的取值向量可能只相差一个很短的向量。

示例 1.3　贯穿例：两个几乎相同的特征　设三个样本上有两个特征，取值向量分别是 $\boldsymbol{c}_1$ 与 $\boldsymbol{c}_2$；另取辅助向量 $\boldsymbol{q}$：

$$\boldsymbol{c}_1 = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}, \qquad \boldsymbol{c}_2 = \begin{pmatrix} 1 \\ 1+\varepsilon \\ 1-\varepsilon \end{pmatrix}, \qquad \boldsymbol{q} = \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix},$$

其中 ε 是一个实参数。第一个特征在三个样本上都取 1；第二个特征在第一个样本上也取 1，在后两个样本上分别多出 ε 和少了 ε。$\boldsymbol{q}$ 恰好记录了这种偏离的模式，逐坐标计算可得

$$\boldsymbol{c}_1 + \varepsilon \boldsymbol{q} = \begin{pmatrix} 1+0 \\ 1+\varepsilon \\ 1-\varepsilon \end{pmatrix} = \boldsymbol{c}_2.$$

于是 $\boldsymbol{c}_2 = \boldsymbol{c}_1 + \varepsilon \boldsymbol{q}$，第二个特征的取值向量是 $\boldsymbol{c}_1$ 与 $\boldsymbol{q}$ 以 1 和 ε 为系数的线性组合。$|\varepsilon|$ 很小时，两者只相差短向量 $\varepsilon \boldsymbol{q}$，几乎是同一串数。

说两个向量的方向“几乎相同”，需要先有夹角的概念；第 3.4.1节用内积定义夹角以后再说明。

1.1.2.3 加法与数乘的性质

加法与数乘是逐坐标定义的，只用到实数的加法与乘法。因此下面每一条规则，都可以在任一坐标上用实数运算直接验证。设 $\boldsymbol{u}, \boldsymbol{v}, \boldsymbol{w} \in \mathbb{R}^d$，$a, b \in \mathbb{R}$。

加法交换律与结合律

$$\boldsymbol{u} + \boldsymbol{v} = \boldsymbol{v} + \boldsymbol{u},$$
$$(\boldsymbol{u} + \boldsymbol{v}) + \boldsymbol{w} = \boldsymbol{u} + (\boldsymbol{v} + \boldsymbol{w}).$$

零向量与相反向量

$$\boldsymbol{u} + \boldsymbol{0} = \boldsymbol{u},$$
$$\boldsymbol{u} + (-\boldsymbol{u}) = \boldsymbol{0}.$$

数乘结合律与单位数

$$a(b\boldsymbol{u}) = (ab)\boldsymbol{u},$$
$$1\boldsymbol{u} = \boldsymbol{u}.$$

分配律

$$(a+b)\boldsymbol{u} = a\boldsymbol{u} + b\boldsymbol{u},$$
$$a(\boldsymbol{u} + \boldsymbol{v}) = a\boldsymbol{u} + a\boldsymbol{v}.$$

有了这八条规则，有限次加法与数乘可以任意加括号、交换加项次序并展开，结果不变；线性组合因此可以像多项式一样合并同类项。下一节的同形矩阵、第 1.4节的多维数组也逐项相加与数乘，同样的验证对它们照样成立。第 2章将看到，后面许多结论只依赖这八条规则，而不依赖对象是一列数还是一张表。

1.1.3　内积、长度与距离

加法与数乘的结果仍是向量。数据分析还常要把两个向量配成一个数，或用一个数衡量一个向量的大小。本小节给出欧氏内积、长度、距离和 p 范数的坐标公式；它们的一般性质在第 3章统一证明。

1.1.3.1　内积

线性预测对一次观测的输入 $x_1,\dots,x_d$ 和一组权重 $w_1,\dots,w_d$ 计算加权和 $\sum_j x_j w_j$，即两串数逐项相乘再相加。这种运算单独定义如下：对 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^d$，标准坐标下的欧氏内积为

$$\langle \boldsymbol{x},\boldsymbol{y}\rangle = \sum_{j=1}^{d} x_j y_j,$$

也写作 $\boldsymbol{x}^{\top}\boldsymbol{y}$。输入是两个同维向量，输出是一个标量。第 1.2节将说明，$\boldsymbol{x}^{\top}\boldsymbol{y}$ 正是 $1\times d$ 矩阵与 $d\times 1$ 矩阵的乘积。

内积为零的情形有专门的名称：$\langle \boldsymbol{x},\boldsymbol{y}\rangle = 0$ 时，称两向量**正交**（orthogonal）。下面先计算一个内积，再检查平面上两对向量是否正交。

示例 1.4　内积与正交的计算　在 $\mathbb{R}^2$ 中取三对向量：$(2,-1)^{\top}$ 与 $(3,4)^{\top}$，标准坐标向量 $\boldsymbol{e}_1=(1,0)^{\top}$ 与 $\boldsymbol{e}_2=(0,1)^{\top}$，以及 $(1,1)^{\top}$ 与 $(1,-1)^{\top}$。对每一对都按定义逐项相乘再相加：

$$\left\langle \begin{pmatrix}2\\-1\end{pmatrix}, \begin{pmatrix}3\\4\end{pmatrix} \right\rangle = 2\cdot 3 + (-1)\cdot 4 = 2,$$

$$\langle \boldsymbol{e}_1,\boldsymbol{e}_2\rangle = \left\langle \begin{pmatrix}1\\0\end{pmatrix}, \begin{pmatrix}0\\1\end{pmatrix} \right\rangle = 1\cdot 0 + 0\cdot 1 = 0,$$

$$\left\langle \begin{pmatrix}1\\1\end{pmatrix}, \begin{pmatrix}1\\-1\end{pmatrix} \right\rangle = 1\cdot 1 + 1\cdot(-1) = 0.$$

第一对的内积为 2，不正交；后两对的内积为零，因而正交。画在平面上，$\boldsymbol{e}_1,\boldsymbol{e}_2$ 沿两条坐标轴，$(1,1)^{\top},(1,-1)^{\top}$ 沿两条对角线，两对确实都互相垂直。

在平面上，正交恰好就是垂直。一般维数下为什么也可以这样理解，要等第 3.4.1节定义夹角以后才能说明。

1.1.3.2 长度与距离

向量与自身的内积 $\langle \boldsymbol{x}, \boldsymbol{x} \rangle = \sum_j x_j^2$ 是各坐标的平方和，总是非负，可以开平方。开平方后得到向量的长度

$$\|\boldsymbol{x}\| = \sqrt{\langle \boldsymbol{x}, \boldsymbol{x} \rangle}. \tag{1.1}$$

由标准内积给出的长度称为欧氏范数（Euclidean norm）或 2 范数，记作

$$\|\boldsymbol{x}\|_2 = \sqrt{\sum_{j=1}^{d} x_j^2}.$$

它把平面上的勾股定理推广到 d 个坐标。

长度为 1 的向量称为单位向量。非零向量 $\boldsymbol{x}$ 除以自身长度，得到 $\boldsymbol{x}/\|\boldsymbol{x}\|_2$。它的各坐标平方和为 1，是一个单位向量；它与 $\boldsymbol{x}$ 方向相同，只是去掉了大小。

两点之间的距离用差向量的长度衡量：$\boldsymbol{x}$ 与 $\boldsymbol{y}$ 的欧氏距离定义为 $\|\boldsymbol{x} - \boldsymbol{y}\|_2$。下面计算前面残差向量的长度，以及平面上两点的距离。

示例 1.5　长度与距离的计算　先回到示例 1.2中 $w = 1$ 时的残差 $\boldsymbol{r} = (1, -2, -3)^{\mathsf{T}}$，计算它长度的平方；再计算平面上两点 $(1, 2)^{\mathsf{T}}$ 与 $(4, 6)^{\mathsf{T}}$ 之差的长度：

$$\|\boldsymbol{r}\|_2^2 = 1^2 + (-2)^2 + (-3)^2 = 14,$$

$$\left\| \begin{pmatrix} 1 \\ 2 \end{pmatrix} - \begin{pmatrix} 4 \\ 6 \end{pmatrix} \right\|_2 = \sqrt{(-3)^2 + (-4)^2} = 5.$$

$\boldsymbol{r}$ 的各坐标是三次观测的预测误差，所以 $\|\boldsymbol{r}\|_2^2 = 14$ 正是 $w = 1$ 时的平方误差总和。第二个算式中，差向量的两个坐标 $-3, -4$ 是直角三角形的两条直角边，距离 5 就是勾股定理给出的斜边长。

用距离比较实际数据时，应先约定各坐标的单位和尺度，否则数值大的坐标会支配距离。

1.1.3.3 范数

欧氏长度先把各坐标平方再相加。衡量向量大小还有别的做法：可以累加各坐标的绝对值，也可以只看最大的绝对值。这些大小度量统称为范数，适合衡量不同含义的误差。

有限维中最常用的是 p 范数：

$$\|\boldsymbol{x}\|_p = \left(\sum_j |x_j|^p\right)^{1/p} \qquad (1 \le p < \infty),$$

$$\|\boldsymbol{x}\|_\infty = \max_j |x_j|.$$

$p = 1$ 时累加绝对偏差；$p = 2$ 时累加平方偏差再开方，就是欧氏长度；$p = \infty$ 时取最大的坐标偏差。下面在同一个向量上比较这三种范数。

示例 1.6　三种 p 范数的计算　取 $\boldsymbol{x} = (3, -4)^\top$，分别按三种方式汇总它的两个坐标：

$$\|\boldsymbol{x}\|_1 = |3| + |-4| = 7,$$

$$\|\boldsymbol{x}\|_2 = \sqrt{3^2 + (-4)^2} = 5,$$

$$\|\boldsymbol{x}\|_\infty = \max\{|3|, |-4|\} = 4.$$

同一个向量在三种范数下的大小依次为 7、5、4。1 范数把两个绝对偏差全部累加，∞ 范数只记最大的那个，2 范数介于两者之间。所以说一个向量“有多大”，要先说明用的是哪种范数。

不同的范数也给出不同形状的单位球 $\{\boldsymbol{x} : \|\boldsymbol{x}\| \le 1\}$，图 1.1把三种单位球并排比较。$p$ 范数的非负性、正定性与齐次性可以直接从公式看出，三角不等式在定理 3.3中证明。

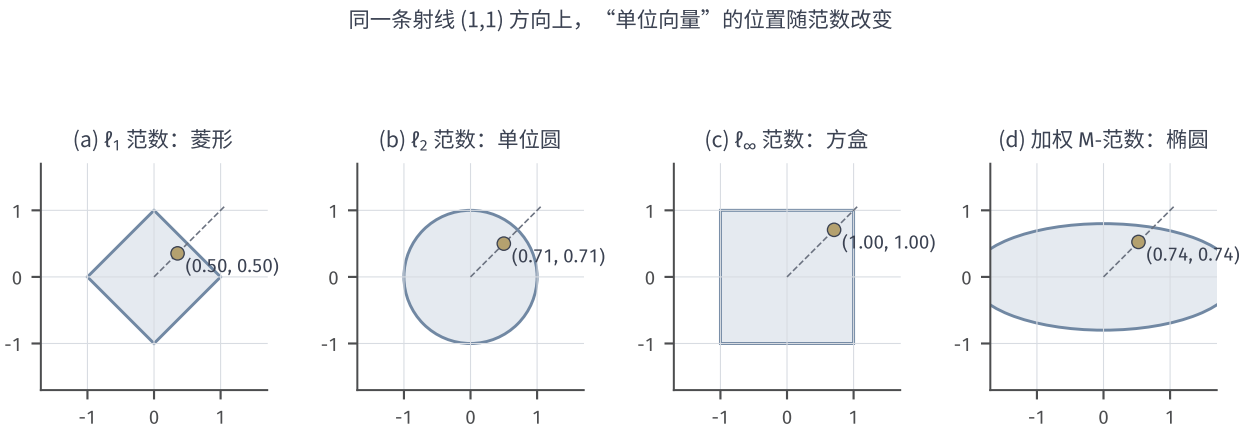


图 1.1　三种范数的单位球。左：ℓ_1 单位球为菱形（累加绝对偏差）；中：ℓ_2 单位球为圆（欧氏长度）；右：ℓ_∞ 单位球为正方形（最大坐标偏差）。同一个点 $(1, 1)$ 的三种范数依次为 2、$\sqrt{2}$、1。三者之间的倍数关系见第 3.1.1节。三图坐标尺度相同，为解析教学例。

本节建立了坐标向量的基本计算：加法、数乘与线性组合产生新的向量，欧氏内积把两个向量配成一个数，范数衡量向量的大小。把若干向量并排放在一起，就得到下一节的矩阵。

1.2 矩阵

一批样本的特征排成一张数表以后，常要对每个样本用同一组权重求加权和。矩阵就是这样的数表，矩阵乘法则一次写出这些加权和。

本节先规定矩阵的写法，再逐个讨论矩阵的运算，每种运算都先给定义、再整理性质。重点是矩阵乘法：它保留了实数乘法的结合律与分配律，却失去了交换律与消去律。最后三小节用乘法回答三个具体问题：怎样用可撤销的步骤化简矩阵，怎样撤销一次乘法，怎样记录同一矩阵的反复作用。

1.2.1 矩阵的表示与常见矩阵

向量中的一个数用一个索引定位。数表中的一个数要由所在的行与列共同确定，需要两个索引。

矩阵、元素与形状 m 行 d 列的实数表称为矩阵（matrix），记为 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$。第 i 行、第 j 列的元素记为 $\boldsymbol{A}_{i,j}$，不致混淆时也写作 $a_{i,j}$。$m\times d$ 称为矩阵的形状，行数写在前，列数写在后。$\boldsymbol{A}_{i,:}$ 表示第 i 行，$\boldsymbol{A}_{:,j}$ 表示第 j 列，冒号表示取该方向上的全部位置；第 j 列是 m 维列向量，第 i 行是 d 维行向量。例如在

$$\boldsymbol{A}=\begin{bmatrix}1&2&3\\4&5&6\end{bmatrix}\in\mathbb{R}^{2\times 3}$$

中，$\boldsymbol{A}_{2,1}=4$，第一行 $\boldsymbol{A}_{1,:}=[1\ 2\ 3]$，第三列 $\boldsymbol{A}_{:,3}=(3,6)^{\top}$。

两个矩阵相等，是指形状相同且每个对应元素相等。

只有一行的矩阵就是行向量，只有一列的矩阵就是列向量，所以向量可以看作矩阵的特例。

设计矩阵 用矩阵记录数据时，通常让每行对应一个样本，每列对应一个特征，这样的矩阵称为设计矩阵。把示例 1.3中的 $\boldsymbol{c}_1,\boldsymbol{c}_2$ 并排作为两列，得到三个样本、两个特征的设计矩阵

$$\boldsymbol{X}_{\varepsilon}=\begin{bmatrix}\boldsymbol{c}_1&\boldsymbol{c}_2\end{bmatrix}=\begin{bmatrix}1&1\\1&1+\varepsilon\\1&1-\varepsilon\end{bmatrix},\qquad \boldsymbol{c}_2=\boldsymbol{c}_1+\varepsilon\boldsymbol{q}. \tag{1.2}$$

后面各章反复用这个矩阵考察两列几乎相同时会出现什么问题。

1.2.1.1 常见矩阵

有些矩阵的元素有固定的分布模式：大部分位置为零，或者关于主对角线对称。这些模式会让后面的运算大为简化。下面按元素的位置与取值逐类给出定义和例子；它们在矩阵乘法下呈现的固定模式，在第 1.2.5.3节随乘法讨论。依赖内积的正交矩阵与正定矩阵在第 3章建立。

方阵　行数等于列数的矩阵称为方阵（square matrix），$n \times n$ 方阵也称 n 阶方阵。位置 (i, i) 上的元素组成主对角线。例如

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

是二阶方阵，主对角元素为 1 和 4；2×3 矩阵不是方阵。下面的对角矩阵和三角矩阵都限定为方阵。

零矩阵　全部元素都为 0 的矩阵称为零矩阵（zero matrix），记作 $\mathbf{0}$。它不要求是方阵，需要时写明形状，例如

$$\mathbf{0}_{2\times 3} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}.$$

对角矩阵　主对角线以外的元素都为 0 的方阵称为对角矩阵（diagonal matrix），记为 $\operatorname{diag}(d_1, \dots, d_n)$。主对角元素本身可以为 0。例如

$$\operatorname{diag}(2, 0) = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix},$$

$$\operatorname{diag}(1, -1, 3) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 3 \end{bmatrix}.$$

单位矩阵　主对角元素全为 1 的对角矩阵称为单位矩阵（identity matrix），记为 $\boldsymbol{I}_n$；不必强调阶数时写作 $\boldsymbol{I}$。它的第 j 列就是标准坐标向量 $\boldsymbol{e}_j$。例如

$$\boldsymbol{I}_3 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} \boldsymbol{e}_1 & \boldsymbol{e}_2 & \boldsymbol{e}_3 \end{bmatrix}.$$

上三角矩阵 $i > j$ 时 $\boldsymbol{A}_{i,j} = 0$ 的方阵称为上三角矩阵（upper triangular matrix）。它的主对角线以下全为零，非零元素只可能出现在主对角线及其上方。例如

$$\begin{bmatrix} 1 & 2 & 3 \\ 0 & 4 & 5 \\ 0 & 0 & 6 \end{bmatrix}.$$

下三角矩阵 $i < j$ 时 $\boldsymbol{A}_{i,j} = 0$ 的方阵称为下三角矩阵（lower triangular matrix），它的主对角线以上全为零。例如

$$\begin{bmatrix} 1 & 0 & 0 \\ 2 & 3 & 0 \\ 4 & 5 & 6 \end{bmatrix}.$$

对角矩阵既是上三角矩阵，也是下三角矩阵。

对称矩阵 若方阵满足 $\boldsymbol{A}_{i,j} = \boldsymbol{A}_{j,i}$ 对全部 i, j 成立，就称为对称矩阵（symmetric matrix）。它的元素关于主对角线镜像对称。定义转置以后，这个条件可以写作 $\boldsymbol{A}^\top = \boldsymbol{A}$。例如

$$\begin{bmatrix} 1 & 2 \\ 2 & 3 \end{bmatrix}, \quad \begin{bmatrix} 4 & -1 & 0 \\ -1 & 2 & 5 \\ 0 & 5 & 1 \end{bmatrix}.$$

对角矩阵都是对称矩阵。

置换矩阵 把单位矩阵的各列重新排列，得到的方阵称为置换矩阵（permutation matrix）。它的每行、每列恰有一个 1，其余元素为 0。例如

$$\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} \boldsymbol{e}_2 & \boldsymbol{e}_1 \end{bmatrix}, \quad \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} = \begin{bmatrix} \boldsymbol{e}_2 & \boldsymbol{e}_3 & \boldsymbol{e}_1 \end{bmatrix}.$$

定义矩阵乘法以后会看到，第一个矩阵乘在平面向量上，交换它的两个坐标。

1.2.2 加法与数乘

矩阵的加法与数乘沿用向量的逐项规则。同形矩阵 $\boldsymbol{A}, \boldsymbol{B} \in \mathbb{R}^{m \times n}$ 逐项相加减，数乘把每个元素乘以同一个实数 c：

$$(\boldsymbol{A} \pm \boldsymbol{B})_{i,j} = a_{i,j} \pm b_{i,j},$$
$$(c\boldsymbol{A})_{i,j} = c a_{i,j}.$$

结果的形状不变。下面是一组二阶矩阵的算例。

示例 1.7　矩阵的加法、减法与数乘　取

$$\boldsymbol{A}=\begin{pmatrix}1 & 2\\ 3 & 4\end{pmatrix},\qquad \boldsymbol{B}=\begin{pmatrix}0 & 1\\ -1 & 2\end{pmatrix},\qquad c=3.$$

每个位置上的元素单独运算：

$$\boldsymbol{A}+\boldsymbol{B}=\begin{pmatrix}1 & 3\\ 2 & 6\end{pmatrix},$$

$$\boldsymbol{A}-\boldsymbol{B}=\begin{pmatrix}1 & 1\\ 4 & 2\end{pmatrix},$$

$$3\boldsymbol{A}=\begin{pmatrix}3 & 6\\ 9 & 12\end{pmatrix}.$$

以 $(2,1)$ 位置为例，$\boldsymbol{A}+\boldsymbol{B}$ 在这里是 $3+(-1)=2$，$\boldsymbol{A}-\boldsymbol{B}$ 在这里是 $3-(-1)=4$，都只用到 $\boldsymbol{A}$ 与 $\boldsymbol{B}$ 的 $(2,1)$ 元。三个结果仍是 2×2 矩阵，这和向量的逐坐标运算完全一样。

与向量一样，两个矩阵相加，要求形状相同、对应位置含义相同。2×3 矩阵与 3×2 矩阵的元素个数相同，却不能相加。同形矩阵的线性组合按同样方式定义。

1.2.2.1　加法与数乘的性质

同形矩阵逐项相加与数乘，所以向量的八条规则在每个位置上照样成立。对同形矩阵 $\boldsymbol{A},\boldsymbol{B},\boldsymbol{C}$ 和实数 a,b，

$$\begin{aligned}
&\boldsymbol{A}+\boldsymbol{B}=\boldsymbol{B}+\boldsymbol{A}, && (\boldsymbol{A}+\boldsymbol{B})+\boldsymbol{C}=\boldsymbol{A}+(\boldsymbol{B}+\boldsymbol{C}),\\
&\boldsymbol{A}+\boldsymbol{0}=\boldsymbol{A}, && \boldsymbol{A}+(-\boldsymbol{A})=\boldsymbol{0},\\
&a(b\boldsymbol{A})=(ab)\boldsymbol{A}, && 1\boldsymbol{A}=\boldsymbol{A},\\
&(a+b)\boldsymbol{A}=a\boldsymbol{A}+b\boldsymbol{A}, && a(\boldsymbol{A}+\boldsymbol{B})=a\boldsymbol{A}+a\boldsymbol{B}.
\end{aligned}$$

每一条都可以在任一位置 (i,j) 上用实数运算直接验证。

1.2.3　转置

转置交换行与列：$\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 的元素 $a_{i,j}$ 原样搬到 $\boldsymbol{A}^{\mathsf{T}}\in\mathbb{R}^{n\times m}$ 的位置 (j,i)，

$$(\boldsymbol{A}^{\mathsf{T}})_{j,i}=\boldsymbol{A}_{i,j}.$$

形状随之交换，数值不变，原来的第 i 行成为第 i 列。把列向量看作 $d\times 1$ 矩阵，这一定义与上一节向量的转置一致。下面的例子显示行怎样变成列。

示例 1.8　转置一个 2×3 矩阵　把

$$\boldsymbol{A}=\begin{bmatrix}1 & 2 & 3\\ 4 & 5 & 6\end{bmatrix}\in\mathbb{R}^{2\times 3}$$

的每个 (i,j) 元搬到 (j,i) 位置，得到

$$\boldsymbol{A}^{\top}=\begin{bmatrix}1 & 4\\ 2 & 5\\ 3 & 6\end{bmatrix}\in\mathbb{R}^{3\times 2}.$$

$\boldsymbol{A}$ 的第一行 $(1,2,3)$ 竖了起来，成为 $\boldsymbol{A}^{\top}$ 的第一列；第二行 $(4,5,6)$ 成为第二列。形状也随之由 2×3 变为 3×2。

1.2.3.1 转置的性质

转置只改变元素的位置。下面两条说明它与加法、数乘的关系，以及转置两次的结果；它与矩阵乘积的关系要等定义了矩阵乘法以后，在第 1.2.5.2节讨论。

与加法、数乘交换

$$(\boldsymbol{A}+\boldsymbol{B})^{\top}=\boldsymbol{A}^{\top}+\boldsymbol{B}^{\top},$$
$$(c\boldsymbol{A})^{\top}=c\boldsymbol{A}^{\top}.$$

转置只搬动元素，逐项运算的结果搬到新位置后不变。

转置的转置

$$(\boldsymbol{A}^{\top})^{\top}=\boldsymbol{A}.$$

转置两次，(i,j) 元先搬到 (j,i)，再搬回 (i,j)，每个元素回到原位。

1.2.4 矩阵与向量的乘积

设 n 次观测的输入排成设计矩阵 $\boldsymbol{X}\in\mathbb{R}^{n\times d}$，权重排成 $\boldsymbol{w}\in\mathbb{R}^{d}$。线性预测对第 i 次观测计算加权和 $\sum_j x_{i,j}w_j$，也就是 $\boldsymbol{X}$ 的第 i 行与 $\boldsymbol{w}$ 的内积。矩阵与向量的乘积把这 n 个加权和一次写出。对 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$ 与 $\boldsymbol{u}\in\mathbb{R}^{d}$，$\boldsymbol{Au}$ 是 m 维列向量，

$$(\boldsymbol{Au})_i=\sum_{j=1}^{d}\boldsymbol{A}_{i,j}u_j,\qquad i=1,\dots,m. \tag{1.3}$$

这里矩阵的列数必须等于向量的维数。

同一个乘积可以按行算，也可以按列算，两者结果相同：

- 按行算：输出的第 i 个坐标是第 i 行与 $\boldsymbol{u}$ 的内积。
- 按列算：式 (1.3)中，u_j 乘的恰好是第 j 列的各个元素，所以

$$\boldsymbol{A}\boldsymbol{u} = u_1\boldsymbol{A}_{:,1} + u_2\boldsymbol{A}_{:,2} + \cdots + u_d\boldsymbol{A}_{:,d},$$

即乘积是矩阵各列以 u_j 为系数的线性组合。

按列算还说明，$\boldsymbol{e}_j$ 只有第 j 个系数为 1，所以 $\boldsymbol{A}\boldsymbol{e}_j = \boldsymbol{A}_{:,j}$：乘第 j 个标准坐标向量，就取出第 j 列。对贯穿例，按列算得 $\boldsymbol{X}_\varepsilon\boldsymbol{w} = w_1\boldsymbol{c}_1 + w_2\boldsymbol{c}_2$，预测是两个特征取值向量的线性组合。

下面用一个二阶例子核对两种算法给出同一结果。

示例 1.9　按行与按列计算矩阵与向量的乘积　取

$$\boldsymbol{A} = \begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix}, \qquad \boldsymbol{u} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

下面第一行算式按行算，每个坐标是 $\boldsymbol{A}$ 的一行与 $\boldsymbol{u}$ 的内积；第二行算式按列算，把 $\boldsymbol{A}$ 的两列以 $u_1 = u_2 = 1$ 为系数组合起来：

$$\boldsymbol{A}\boldsymbol{u} = \begin{bmatrix} 2\cdot 1 + 1\cdot 1 \\ 0\cdot 1 + 3\cdot 1 \end{bmatrix} = \begin{bmatrix} 3 \\ 3 \end{bmatrix},$$

$$\boldsymbol{A}\boldsymbol{u} = 1\begin{bmatrix} 2 \\ 0 \end{bmatrix} + 1\begin{bmatrix} 1 \\ 3 \end{bmatrix} = \begin{bmatrix} 3 \\ 3 \end{bmatrix}.$$

两种算法都得到 $(3,3)^{\mathsf{T}}$。按行算的每一项乘积，在按列算中也恰好出现一次，只是加起来的顺序不同。

用于数据时，一次矩阵与向量的乘积给出全部样本的预测。下面以一次函数为例。

示例 1.10　用矩阵与向量的乘积计算一次函数的取值与残差　设要在 $x = 1, 2, 3$ 三处计算一次函数 $ax + b$ 的值。把三处的 x 排成第一列、再补上一列 1，系数排成向量，即

$$\boldsymbol{X} = \begin{pmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \end{pmatrix}, \qquad \boldsymbol{w} = \begin{pmatrix} a \\ b \end{pmatrix}.$$

按行算，

$$\boldsymbol{X}\boldsymbol{w} = \begin{pmatrix} 1\cdot a + 1\cdot b \\ 2\cdot a + 1\cdot b \\ 3\cdot a + 1\cdot b \end{pmatrix} = \begin{pmatrix} a+b \\ 2a+b \\ 3a+b \end{pmatrix}.$$

$\boldsymbol{X}\boldsymbol{w}$ 的三个坐标正是三处的函数值；第二列全为 1，使每行都加上同一个截距 b。再把三处的观测输出排成 $\boldsymbol{y} = (y_1, y_2, y_3)^{\mathsf{T}}$，全部残差就是 $\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y}$，平方误差总和写成

$$\sum_{i=1}^{3} \bigl(a\,i + b - y_i\bigr)^2 = \|\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y}\|_2^2.$$

左侧逐处求函数值、减去观测、平方后相加；右侧把同样的计算写成残差向量长度的平方。

这里只用到乘积按行展开和长度的定义，与样本数、特征数无关。n 个样本、d 个特征时同样有

$$\sum_{i=1}^{n} \Bigl(\sum_{j=1}^{d} x_{i,j} w_j - y_i\Bigr)^2 = \|\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y}\|_2^2.$$

于是一次矩阵与向量的乘积给出全部预测，平方误差总和则是残差向量长度的平方。

1.2.5 矩阵乘法

两次加权求和可能接连进行。设 $\boldsymbol{B} \in \mathbb{R}^{d\times k}$，$\boldsymbol{A} \in \mathbb{R}^{m\times d}$。对 $\boldsymbol{x} \in \mathbb{R}^k$，先算 $\boldsymbol{y} = \boldsymbol{B}\boldsymbol{x}$，再算 $\boldsymbol{z} = \boldsymbol{A}\boldsymbol{y}$。这就是两个映射的复合：$\boldsymbol{x} \mapsto \boldsymbol{B}\boldsymbol{x}$ 的输出 $\boldsymbol{y}$ 恰好落在 $\boldsymbol{y} \mapsto \boldsymbol{A}\boldsymbol{y}$ 的定义域 $\mathbb{R}^d$ 中，复合映射把 $\boldsymbol{x}$ 直接送到 $\boldsymbol{A}(\boldsymbol{B}\boldsymbol{x})$；映射复合的一般定义可参考卷一第 1 章“集合、关系与映射”。

逐坐标代入，再交换有限求和的次序，得到

$$z_i = \sum_{\ell=1}^{d} a_{i,\ell} \sum_{j=1}^{k} b_{\ell,j} x_j = \sum_{j=1}^{k} \left(\sum_{\ell=1}^{d} a_{i,\ell} b_{\ell,j} \right) x_j. \tag{1.4}$$

可见 $\boldsymbol{z}$ 仍是 $\boldsymbol{x}$ 各坐标的加权和。把括号中的系数排成一张表，就得到矩阵乘法的定义。

对 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$ 与 $\boldsymbol{B} \in \mathbb{R}^{d\times k}$，乘积 $\boldsymbol{A}\boldsymbol{B} \in \mathbb{R}^{m\times k}$ 定义为

$$(\boldsymbol{A}\boldsymbol{B})_{i,j} = \sum_{\ell=1}^{d} \boldsymbol{A}_{i,\ell} \boldsymbol{B}_{\ell,j}. \tag{1.5}$$

左矩阵的列数必须等于右矩阵的行数。第 (i,j) 项取左矩阵的第 i 行与右矩阵的第 j 列，逐项相乘后相加。被求和掉的公共维数 d，就是中间结果 $\boldsymbol{y}$ 的维数。$\boldsymbol{B}$ 只有一列时，式 (1.5)就是式 (1.3)。两个向量的内积 $\boldsymbol{x}^{\top}\boldsymbol{y}$ 是 $1\times d$ 矩阵与 $d\times 1$ 矩阵的乘积，结果是 1×1 矩阵，我们把它与其唯一的元素等同看待。

非方阵相乘时，写出每个因子的形状尤其有用。以 2×3 矩阵乘 3×2 矩阵为例，

$$
\begin{aligned}
&\begin{pmatrix} 1 & 2 & 0 \\ 0 & 1 & 3 \end{pmatrix}
\begin{pmatrix} 1 & 0 \\ 2 & 1 \\ 1 & -1 \end{pmatrix} \\
&= \begin{pmatrix} 1\cdot 1 + 2\cdot 2 + 0\cdot 1 & 1\cdot 0 + 2\cdot 1 + 0\cdot(-1) \\ 0\cdot 1 + 1\cdot 2 + 3\cdot 1 & 0\cdot 0 + 1\cdot 1 + 3\cdot(-1) \end{pmatrix} \\
&= \begin{pmatrix} 5 & 2 \\ 5 & -2 \end{pmatrix}.
\end{aligned}
$$

左矩阵的列数与右矩阵的行数都是 3，乘法有定义；输出保留左矩阵的 2 行和右矩阵的 2 列。若这两个数不相等，行与列就无法逐项配对。

1.2.5.1 矩阵乘法的性质

矩阵乘法保留了实数乘法的结合律和分配律，但一般不满足交换律和消去律。下面逐条核对，并检查每条规则对形状的要求。

单位乘

$$\boldsymbol{I}_m\boldsymbol{A} = \boldsymbol{A} = \boldsymbol{A}\boldsymbol{I}_d, \qquad \boldsymbol{A}\in\mathbb{R}^{m\times d}.$$

$\boldsymbol{I}_m$ 的第 i 行是 $\boldsymbol{e}_i^{\top}$，它乘 $\boldsymbol{A}$ 的第 j 列，取出 $a_{i,j}$；右乘同理。单位矩阵在矩阵乘法中的作用，相当于数 1 在实数乘法中的作用。

零乘

$$\boldsymbol{0}\boldsymbol{A} = \boldsymbol{0}, \qquad \boldsymbol{A}\boldsymbol{0} = \boldsymbol{0}.$$

乘积的每个元素都是若干乘积之和。一个因子全为零时，每一项都为零。各个零矩阵的形状由相乘的另一个因子决定。

反过来不成立：由 $\boldsymbol{A}\boldsymbol{B}=\boldsymbol{0}$ 不能推出 $\boldsymbol{A}=\boldsymbol{0}$ 或 $\boldsymbol{B}=\boldsymbol{0}$。下面是一个反例。

示例 1.11　反例：两个非零矩阵的乘积为零　两个二阶矩阵

$$\boldsymbol{A}=\begin{bmatrix}1&0\\0&0\end{bmatrix},\qquad \boldsymbol{B}=\begin{bmatrix}0&0\\1&0\end{bmatrix}$$

各有一个非零元，都不是零矩阵。按定义相乘，

$$\boldsymbol{AB}=\begin{bmatrix}1\cdot0+0\cdot1&1\cdot0+0\cdot0\\0\cdot0+0\cdot1&0\cdot0+0\cdot0\end{bmatrix}=\begin{bmatrix}0&0\\0&0\end{bmatrix}.$$

四个元素全为零。可见两个非零因子的乘积可以是零矩阵，实数中“乘积为零则必有一个因子为零”的推理不能搬到矩阵上。

按列看可以说明原因。由乘积的元素公式，$\boldsymbol{AB}$ 的第 j 列就是 $\boldsymbol{A}$ 乘 $\boldsymbol{B}$ 的第 j 列。所以 $\boldsymbol{AB}=\boldsymbol{0}$ 恰好意味着 $\boldsymbol{B}$ 的每一列 $\boldsymbol{b}$ 都满足 $\boldsymbol{Ab}=\boldsymbol{0}$。上例中 $\boldsymbol{A}$ 只保留第一个坐标、把第二个坐标清零；$\boldsymbol{B}$ 的第一列 $(0,1)^{\mathsf{T}}$ 只有第二个坐标非零，第二列为零，于是两列都被 $\boldsymbol{A}$ 清零。

结合律

$$(\boldsymbol{AB})\boldsymbol{C}=\boldsymbol{A}(\boldsymbol{BC}).$$

按式 (1.5)展开，两边的第 (i,j) 项都是 $\sum_k\sum_l a_{i,k}b_{k,l}c_{l,j}$，只是两个有限求和的次序不同。从映射的角度看，这就是复合的结合律：先作用 $\boldsymbol{C}$、再作用 $\boldsymbol{B}$、最后作用 $\boldsymbol{A}$，无论先把哪两步合并，得到的都是同一个映射。取 $\boldsymbol{C}$ 为列向量 $\boldsymbol{x}$，得 $(\boldsymbol{AB})\boldsymbol{x}=\boldsymbol{A}(\boldsymbol{Bx})$：用乘积作用一次，等于先用 $\boldsymbol{B}$、再用 $\boldsymbol{A}$ 作用。这正是式 (1.4)引出乘法定义时的计算。有了结合律，多个形状相容的矩阵连乘时不必加括号。

分配律与数乘相容

$$\boldsymbol{A}(\boldsymbol{B}+\boldsymbol{C})=\boldsymbol{AB}+\boldsymbol{AC},$$

$$(\boldsymbol{A}+\boldsymbol{B})\boldsymbol{C}=\boldsymbol{AC}+\boldsymbol{BC},$$

$$c(\boldsymbol{AB})=(c\boldsymbol{A})\boldsymbol{B}=\boldsymbol{A}(c\boldsymbol{B}).$$

逐项展开有限和即得。把右因子取为列向量，就得到矩阵与向量的乘积保持线性组合：

$$\boldsymbol{A}(a\boldsymbol{u}+b\boldsymbol{v})=a\boldsymbol{Au}+b\boldsymbol{Av},\qquad \boldsymbol{u},\boldsymbol{v}\in\mathbb{R}^d,\quad a,b\in\mathbb{R}. \tag{1.6}$$

由这一性质，函数 $\boldsymbol{u}\mapsto\boldsymbol{Au}$ 由它在 $\boldsymbol{e}_1,\dots,\boldsymbol{e}_d$ 上的输出完全确定。因为 $\boldsymbol{u}=\sum_j u_j\boldsymbol{e}_j$，所以 $\boldsymbol{Au}=\sum_j u_j\boldsymbol{Ae}_j$，而这些输出 $\boldsymbol{Ae}_j$ 就是 $\boldsymbol{A}$ 的各列。第 2章把保持线性组合的函数称为线性映射，并说明每个这样的映射都能由一张矩阵记录。

分块乘法　把矩阵按行、列切成尺寸相容的块，乘法公式对块照样成立。以 2×2 分块为例，

$$\begin{bmatrix} \boldsymbol{A}_{1,1} & \boldsymbol{A}_{1,2} \\ \boldsymbol{A}_{2,1} & \boldsymbol{A}_{2,2} \end{bmatrix} \begin{bmatrix} \boldsymbol{B}_{1,1} & \boldsymbol{B}_{1,2} \\ \boldsymbol{B}_{2,1} & \boldsymbol{B}_{2,2} \end{bmatrix} = \begin{bmatrix} \boldsymbol{A}_{1,1}\boldsymbol{B}_{1,1}+\boldsymbol{A}_{1,2}\boldsymbol{B}_{2,1} & \boldsymbol{A}_{1,1}\boldsymbol{B}_{1,2}+\boldsymbol{A}_{1,2}\boldsymbol{B}_{2,2} \\ \boldsymbol{A}_{2,1}\boldsymbol{B}_{1,1}+\boldsymbol{A}_{2,2}\boldsymbol{B}_{2,1} & \boldsymbol{A}_{2,1}\boldsymbol{B}_{1,2}+\boldsymbol{A}_{2,2}\boldsymbol{B}_{2,2} \end{bmatrix}.$$

条件是每对相乘的块中，左块的列数等于右块的行数。理由如下：结果的每一块只用到左因子的一个行块和右因子的一个列块；式 (1.5)中对中间索引 ℓ 的求和可以按列块分段进行，各段之和就是整段的和。块可以像数一样参与运算，只是块的次序不能交换。

把块分到最细，得到三种常用的特例。右因子按列分块，得 $(\boldsymbol{AB})_{:,j}=\boldsymbol{AB}_{:,j}$；左因子按行分块，得 $(\boldsymbol{AB})_{i,:}=\boldsymbol{A}_{i,:}\boldsymbol{B}$；把中间维数 d 切成长度为 1 的 d 段，得到

$$\boldsymbol{AB}=\sum_{\ell=1}^{d}\boldsymbol{A}_{:,\ell}\boldsymbol{B}_{\ell,:}, \tag{1.7}$$

其中一列 $\boldsymbol{A}_{:,\ell}\in\mathbb{R}^{m\times 1}$ 乘一行 $\boldsymbol{B}_{\ell,:}\in\mathbb{R}^{1\times k}$，得到 (i,j) 元素为 $a_{i,\ell}b_{\ell,j}$ 的 $m\times k$ 矩阵。第 15章讨论低秩近似时，就从式 (1.7)出发。下面用一个二阶乘积核对这个公式。

示例 1.12　把乘积写成列乘行之和　取

$$\boldsymbol{A}=\begin{pmatrix}1&1\\0&1\end{pmatrix},\qquad \boldsymbol{B}=\begin{pmatrix}1&0\\0&2\end{pmatrix}.$$

$\boldsymbol{A}$ 的两列为 $(1,0)^{\top}$ 与 $(1,1)^{\top}$，$\boldsymbol{B}$ 的两行为 $(1,0)$ 与 $(0,2)$。把第 ℓ 列与第 ℓ 行配成一对相乘，再把两个结果相加：

$$\boldsymbol{AB}=\begin{pmatrix}1\\0\end{pmatrix}\begin{pmatrix}1&0\end{pmatrix}+\begin{pmatrix}1\\1\end{pmatrix}\begin{pmatrix}0&2\end{pmatrix}=\begin{pmatrix}1&0\\0&0\end{pmatrix}+\begin{pmatrix}0&2\\0&2\end{pmatrix}=\begin{pmatrix}1&2\\0&2\end{pmatrix}.$$

按式 (1.5)逐项计算 $\boldsymbol{AB}$，也得到同一个矩阵。两种算法的区别只在于：逐项计算先固定位置 (i,j)、再对 ℓ 求和，列乘行之和先固定 ℓ、一次写出所有位置上的贡献。

交换律不成立　一般 $\boldsymbol{AB}\neq\boldsymbol{BA}$。形状不同时，两个乘积不一定都有定义；即使两个因子是同阶方阵，两种次序的乘积也可能不同。下面是一个反例。

示例 1.13　反例：先交换再保留与先保留再交换　考虑两个作用很简单的二阶矩阵：$\boldsymbol{P}$ 只保留第一个坐标，$\boldsymbol{S}$ 交换两个坐标，

$$\boldsymbol{P}=\begin{bmatrix}1&0\\0&0\end{bmatrix},\qquad \boldsymbol{S}=\begin{bmatrix}0&1\\1&0\end{bmatrix}.$$

按两种次序相乘，得到

$$\boldsymbol{PS}=\begin{bmatrix}0&1\\0&0\end{bmatrix},\qquad \boldsymbol{SP}=\begin{bmatrix}0&0\\1&0\end{bmatrix},$$

所以 $\boldsymbol{PS}\neq\boldsymbol{SP}$。看它们对 $\boldsymbol{u}\in\mathbb{R}^2$ 的作用，差别的来源就清楚了：$\boldsymbol{PSu}=(u_2,0)^{\mathsf{T}}$ 是先交换、再保留第一个坐标，留下的是 u_2；$\boldsymbol{SPu}=(0,u_1)^{\mathsf{T}}$ 是先保留、再交换，留下的是 u_1，并且被移到了第二个位置。

书写 $\boldsymbol{ABx}$ 时，作用顺序从右向左：先作用 $\boldsymbol{B}$，后作用 $\boldsymbol{A}$。

消去律不成立　由 $\boldsymbol{AB}=\boldsymbol{AC}$ 且 $\boldsymbol{A}\neq\boldsymbol{0}$，不能推出 $\boldsymbol{B}=\boldsymbol{C}$。原因是 $\boldsymbol{AB}=\boldsymbol{AC}$ 等价于 $\boldsymbol{A}(\boldsymbol{B}-\boldsymbol{C})=\boldsymbol{0}$，而乘积为零推不出 $\boldsymbol{B}-\boldsymbol{C}=\boldsymbol{0}$。下面用示例 1.11构造反例。

示例 1.14　反例：非零的左因子不能消去　沿用示例 1.11中的

$$\boldsymbol{A}=\begin{bmatrix}1&0\\0&0\end{bmatrix},\qquad \boldsymbol{B}=\begin{bmatrix}0&0\\1&0\end{bmatrix},$$

再取 $\boldsymbol{C}=\boldsymbol{0}$。那个例子已经算出 $\boldsymbol{AB}=\boldsymbol{0}$，而零乘给出 $\boldsymbol{AC}=\boldsymbol{0}$，所以 $\boldsymbol{AB}=\boldsymbol{AC}$。但 $\boldsymbol{B}\neq\boldsymbol{C}$：尽管 $\boldsymbol{A}\neq\boldsymbol{0}$，等式两边的 $\boldsymbol{A}$ 也不能消去。

如果 $\boldsymbol{A}$ 是可逆方阵（第 1.2.8节），在 $\boldsymbol{AB}=\boldsymbol{AC}$ 两边左乘 $\boldsymbol{A}^{-1}$，就得到 $\boldsymbol{B}=\boldsymbol{C}$。所以可逆的左因子可以消去，一般的非零因子则不能。

1.2.5.2 转置与乘积

第 1.2.3节整理的转置性质只涉及加法、数乘和转置本身。乘法把左因子的行与右因子的列配对求和，而转置交换行与列，因此要单独考察乘积转置以后两个因子怎样排列。下面先给出这条规则，再看它在内积和对称性上的两个推论。

乘积的转置

$$(\boldsymbol{AB})^{\mathsf{T}}=\boldsymbol{B}^{\mathsf{T}}\boldsymbol{A}^{\mathsf{T}}.$$

乘积转置以后，因子的次序反过来。按元素公式，

$$\begin{aligned}\big((\boldsymbol{AB})^{\top}\big)_{i,j} &= (\boldsymbol{AB})_{j,i} \\ &= \sum_{\ell} a_{j,\ell} b_{\ell,i} \\ &= \sum_{\ell} (\boldsymbol{B}^{\top})_{i,\ell} (\boldsymbol{A}^{\top})_{\ell,j} \\ &= (\boldsymbol{B}^{\top}\boldsymbol{A}^{\top})_{i,j}.\end{aligned}$$

多个因子时依次使用这条规则，得 $(\boldsymbol{ABC})^{\top} = \boldsymbol{C}^{\top}\boldsymbol{B}^{\top}\boldsymbol{A}^{\top}$。

内积中的转置

$$\langle \boldsymbol{Ax}, \boldsymbol{y} \rangle = \langle \boldsymbol{x}, \boldsymbol{A}^{\top}\boldsymbol{y} \rangle, \qquad \boldsymbol{A} \in \mathbb{R}^{m\times d},\ \boldsymbol{x} \in \mathbb{R}^{d},\ \boldsymbol{y} \in \mathbb{R}^{m}.$$

由上一条，$(\boldsymbol{Ax})^{\top}\boldsymbol{y} = \boldsymbol{x}^{\top}\boldsymbol{A}^{\top}\boldsymbol{y}$。所以在欧氏内积中，作用在左侧向量上的 $\boldsymbol{A}$，可以改写成作用在右侧向量上的 $\boldsymbol{A}^{\top}$。

$\boldsymbol{A}^{\top}\boldsymbol{A}$ 对称　对任意矩阵 $\boldsymbol{A}$，$\boldsymbol{A}^{\top}\boldsymbol{A}$ 与 $\boldsymbol{AA}^{\top}$ 都是对称矩阵。由乘积的转置，$(\boldsymbol{A}^{\top}\boldsymbol{A})^{\top} = \boldsymbol{A}^{\top}(\boldsymbol{A}^{\top})^{\top} = \boldsymbol{A}^{\top}\boldsymbol{A}$；另一个同理。下面直接算出一个 $\boldsymbol{AA}^{\top}$。

示例 1.15　计算 $\boldsymbol{AA}^{\top}$　取

$$\boldsymbol{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}.$$

$\boldsymbol{A}^{\top}$ 的第 j 列就是 $\boldsymbol{A}$ 的第 j 行，所以 $\boldsymbol{AA}^{\top}$ 的 (i,j) 元是 $\boldsymbol{A}$ 的第 i 行与第 j 行的内积：

$$\boldsymbol{AA}^{\top} = \begin{bmatrix} 1+4+9 & 4+10+18 \\ 4+10+18 & 16+25+36 \end{bmatrix} = \begin{bmatrix} 14 & 32 \\ 32 & 77 \end{bmatrix}.$$

$(1,2)$ 元与 $(2,1)$ 元都是第一、二两行的内积 32；内积与两行的先后无关，所以结果必然对称。对角元 14、77 则是两行各自长度的平方。

1.2.5.3 常见矩阵的乘法

第 1.2.1.1节的几类常见矩阵参与乘法时，结果有固定的模式。下面逐类说明。

对角矩阵的乘法 设 $\boldsymbol{D} = \operatorname{diag}(d_1, \dots, d_n)$。左乘和右乘对角矩阵分别给出

$$(\boldsymbol{D}\boldsymbol{A})_{i,j} = d_i \boldsymbol{A}_{i,j},$$
$$(\boldsymbol{A}\boldsymbol{D})_{i,j} = \boldsymbol{A}_{i,j} d_j.$$

乘积公式中，左乘时只剩 $\ell = i$ 一项，右乘时只剩 $\ell = j$ 一项。所以左乘对角矩阵缩放各行，右乘缩放各列。作用在向量上，$\boldsymbol{D}\boldsymbol{u} = (d_1 u_1, \dots, d_n u_n)^{\mathsf{T}}$ 是逐坐标缩放。两个对角矩阵相乘时，对角元逐个相乘：

$$\operatorname{diag}(d_1, \dots, d_n) \operatorname{diag}(e_1, \dots, e_n) = \operatorname{diag}(d_1 e_1, \dots, d_n e_n).$$

因此对角矩阵之间可以交换次序。下面的例子比较左乘与右乘。

示例 1.16 左乘与右乘对角矩阵 取

$$\boldsymbol{D} = \operatorname{diag}(2, 3), \qquad \boldsymbol{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix},$$

把 $\boldsymbol{D}$ 分别放在 $\boldsymbol{A}$ 的左边和右边：

$$\boldsymbol{D}\boldsymbol{A} = \begin{bmatrix} 2\cdot 1 & 2\cdot 2 \\ 3\cdot 3 & 3\cdot 4 \end{bmatrix} = \begin{bmatrix} 2 & 4 \\ 9 & 12 \end{bmatrix},$$
$$\boldsymbol{A}\boldsymbol{D} = \begin{bmatrix} 1\cdot 2 & 2\cdot 3 \\ 3\cdot 2 & 4\cdot 3 \end{bmatrix} = \begin{bmatrix} 2 & 6 \\ 6 & 12 \end{bmatrix}.$$

左乘把第一、二行分别乘以 2、3，右乘则把第一、二列分别乘以 2、3。两个结果不同：对角矩阵彼此可以交换，与一般矩阵相乘时仍要区分左右。

三角矩阵的乘法 若 $\boldsymbol{A}, \boldsymbol{B}$ 都是 n 阶上三角矩阵，则 $\boldsymbol{A}\boldsymbol{B}$ 也是上三角矩阵，并且

$$(\boldsymbol{A}\boldsymbol{B})_{i,i} = \boldsymbol{A}_{i,i} \boldsymbol{B}_{i,i}.$$

理由如下。在 $(\boldsymbol{A}\boldsymbol{B})_{i,j} = \sum_{\ell} \boldsymbol{A}_{i,\ell} \boldsymbol{B}_{\ell,j}$ 中，$\boldsymbol{A}_{i,\ell}$ 只在 $\ell \geq i$ 时可能非零，$\boldsymbol{B}_{\ell,j}$ 只在 $\ell \leq j$ 时可能非零，所以只有 $i \leq \ell \leq j$ 的项可能非零。$i > j$ 时没有这样的 ℓ，乘积元素为零；$i = j$ 时只剩 $\ell = i$ 一项。下三角矩阵同理：两个下三角矩阵的乘积仍是下三角矩阵，对角元逐个相乘。下面是一个二阶算例。

示例 1.17　两个上三角矩阵的乘积　取两个上三角矩阵

$$\boldsymbol{A}=\begin{bmatrix}1 & 2\\ 0 & 3\end{bmatrix},\qquad \boldsymbol{B}=\begin{bmatrix}4 & 5\\ 0 & 6\end{bmatrix}.$$

它们的乘积为

$$\boldsymbol{AB}=\begin{bmatrix}1\cdot 4+2\cdot 0 & 1\cdot 5+2\cdot 6\\ 0\cdot 4+3\cdot 0 & 0\cdot 5+3\cdot 6\end{bmatrix}=\begin{bmatrix}4 & 17\\ 0 & 18\end{bmatrix}.$$

左下角的 $0\cdot 4+3\cdot 0$ 中，每一项都有一个因子取自主对角线以下的零，所以乘积仍是上三角矩阵。对角元 $4=1\cdot 4$、$18=3\cdot 6$ 只是两个因子对角元的乘积；右上角的 17 则同时用到了两个因子的非对角元，没有这样简单的规律。

置换矩阵的乘法　设 $\boldsymbol{P}=[\,\boldsymbol{e}_{\sigma(1)}\ \cdots\ \boldsymbol{e}_{\sigma(n)}\,]$，其中 σ 是 $\{1,\dots,n\}$ 上的排列，则

$$(\boldsymbol{PA})_{\sigma(i),:}=\boldsymbol{A}_{i,:},$$
$$(\boldsymbol{AP})_{:,j}=\boldsymbol{A}_{:,\sigma(j)}.$$

也就是说，左乘 $\boldsymbol{P}$ 把 $\boldsymbol{A}$ 的第 i 行移到第 $\sigma(i)$ 行；右乘 $\boldsymbol{P}$ 后，第 j 列取自 $\boldsymbol{A}$ 的第 $\sigma(j)$ 列。例如二阶置换矩阵

$$\begin{bmatrix}0 & 1\\ 1 & 0\end{bmatrix}$$

左乘交换两行，右乘交换两列。

两个置换矩阵的乘积仍是置换矩阵。设 $\boldsymbol{P}'$ 是另一个置换矩阵，则 $\boldsymbol{P}'\boldsymbol{P}$ 的第 j 列是 $\boldsymbol{P}'\boldsymbol{e}_{\sigma(j)}$，即 $\boldsymbol{P}'$ 的第 $\sigma(j)$ 列。不同的 j 取到 $\boldsymbol{P}'$ 的不同列，所以 $\boldsymbol{P}'\boldsymbol{P}$ 的各列是互不相同的标准坐标向量，它是单位矩阵各列的一种重排。

对称矩阵的乘积　若 $\boldsymbol{A},\boldsymbol{B}$ 是同阶对称矩阵，则

$$(\boldsymbol{AB})^{\top}=\boldsymbol{B}^{\top}\boldsymbol{A}^{\top}=\boldsymbol{BA},$$

所以 $\boldsymbol{AB}$ 对称当且仅当 $\boldsymbol{AB}=\boldsymbol{BA}$。两个对称矩阵一般不交换，它们的乘积一般也不对称。下面是一个反例。

示例 1.18　反例：两个对称矩阵的乘积不对称　取两个对称矩阵

$$\boldsymbol{A} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}, \qquad \boldsymbol{B} = \operatorname{diag}(1, 2).$$

右乘对角矩阵 $\boldsymbol{B}$ 相当于把 $\boldsymbol{A}$ 的第二列乘以 2，

$$\boldsymbol{AB} = \begin{bmatrix} 1\cdot 1 & 1\cdot 2 \\ 1\cdot 1 & 0\cdot 2 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 1 & 0 \end{bmatrix}.$$

原来关于主对角线对称的两个 1，只有右上角的一个被放大，于是 $(\boldsymbol{AB})_{1,2} = 2 \neq 1 = (\boldsymbol{AB})_{2,1}$，乘积不对称。这与上面的判据一致：换成左乘，$\boldsymbol{B}$ 放大的是第二行，

$$\boldsymbol{BA} = \begin{bmatrix} 1 & 1 \\ 2 & 0 \end{bmatrix} \neq \boldsymbol{AB},$$

两个因子不交换。

1.2.6 逐项乘积

矩阵乘法对公共索引求和。另一种常用的“乘积”不对任何索引求和，只把两个同形数组在同一位置上的元素相乘。

设 $\boldsymbol{A}, \boldsymbol{B} \in \mathbb{R}^{m\times n}$，它们的**逐元素乘积**（Hadamard product）记作 $\boldsymbol{A} \odot \boldsymbol{B}$，

$$(\boldsymbol{A} \odot \boldsymbol{B})_{i,j} = a_{i,j} b_{i,j}. \tag{1.8}$$

输出仍是 $m \times n$ 矩阵。同维向量和更高阶的同形数组也按同样的方式逐项相乘。

对同样两个矩阵，两种乘积的结果完全不同。

示例 1.19　逐项乘积与矩阵乘积的对比　取

$$\boldsymbol{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, \qquad \boldsymbol{B} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix},$$

其中 $\boldsymbol{B}$ 是交换两个坐标的置换矩阵。分别计算两种乘积：

$$\boldsymbol{A} \odot \boldsymbol{B} = \begin{bmatrix} 1\cdot 0 & 2\cdot 1 \\ 3\cdot 1 & 4\cdot 0 \end{bmatrix} = \begin{bmatrix} 0 & 2 \\ 3 & 0 \end{bmatrix},$$

$$\boldsymbol{AB} = \begin{bmatrix} 1\cdot 0 + 2\cdot 1 & 1\cdot 1 + 2\cdot 0 \\ 3\cdot 0 + 4\cdot 1 & 3\cdot 1 + 4\cdot 0 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 4 & 3 \end{bmatrix}.$$

> 逐项乘积保留 $\boldsymbol{A}$ 在 $\boldsymbol{B}$ 取 1 处的元素，把 $\boldsymbol{B}$ 为零的位置置零；矩阵乘积则是右乘置换矩阵，交换了 $\boldsymbol{A}$ 的两列。两个结果在每个位置上都不同。

固定一个掩码矩阵 $\boldsymbol{M}$，运算 $\boldsymbol{X} \mapsto \boldsymbol{M} \odot \boldsymbol{X}$ 把 $\boldsymbol{M}$ 为零的位置置零，把其余位置按 $\boldsymbol{M}$ 的元素缩放。因此逐项乘积适合表达“挑选或调制另一个数组”。

1.2.6.1 逐项乘积的性质

逐项乘积在每个位置上只是实数乘法，所以它的规则都可以逐个位置从实数运算推出。以下矩阵的形状都相同。

交换律

$$\boldsymbol{A} \odot \boldsymbol{B} = \boldsymbol{B} \odot \boldsymbol{A}.$$

式 (1.8)右端是实数乘法，逐个位置验证即得。逐项乘积可交换，矩阵乘积不可交换，这再次说明两者是不同的运算。

结合律

$$(\boldsymbol{A} \odot \boldsymbol{B}) \odot \boldsymbol{C} = \boldsymbol{A} \odot (\boldsymbol{B} \odot \boldsymbol{C}),$$

两边的 (i, j) 元素都是 $a_{i,j} b_{i,j} c_{i,j}$。

分配律

$$\boldsymbol{A} \odot (\boldsymbol{B} + \boldsymbol{C}) = \boldsymbol{A} \odot \boldsymbol{B} + \boldsymbol{A} \odot \boldsymbol{C},$$

两边的 (i, j) 元素都是 $a_{i,j}(b_{i,j} + c_{i,j})$。

单位元是全 1 数组　全部元素为 1 的同形数组 $\boldsymbol{J}$ 满足 $\boldsymbol{J} \odot \boldsymbol{A} = \boldsymbol{A}$。单位矩阵不是逐项乘积的单位元：$\boldsymbol{I}_2 \odot \boldsymbol{A}$ 只保留 $\boldsymbol{A}$ 的对角元，把非对角元都变为零。

对每个因子分别线性　固定一个因子 $\boldsymbol{M}$ 时，$\boldsymbol{X} \mapsto \boldsymbol{M} \odot \boldsymbol{X}$ 保持线性组合。两个因子都可变时，乘积只对每个因子分别线性，对两者整体不是线性的：同时把两个因子放大两倍，结果放大四倍。第 2章还会看到，换一组记录方向以后，矩阵乘积所表示的复合关系保持不变，逐项乘积的结果则随记录方式改变。

1.2.7 初等行变换与阶梯形

解方程和求逆时，需要把一个矩阵逐步化成容易辨认的形式。每一步都应当可以撤销，这样才不会丢失原矩阵中的信息。为此，对矩阵的行只允许三种**初等行变换**（elementary row operation）：交换两行；将一行乘以非零数；将一行加上另一行的倍数。它们都可以撤销：再次交换同两行，乘以原系数的倒数，或减去原来加上的倍数。

每种初等行变换都可以写成左乘一个矩阵。对单位矩阵执行某种行变换，所得矩阵称为初等矩阵，记为 $\boldsymbol{E}$；那么 $\boldsymbol{EA}$ 恰好是对 $\boldsymbol{A}$ 执行同一变换的结果。例如，交换单位矩阵两行得到的矩阵，左乘 $\boldsymbol{A}$ 时交换 $\boldsymbol{A}$ 的对应两行。逆操作也对应一个初等矩阵，所以 $\boldsymbol{E}$ 可逆。

化简时从左到右逐列寻找**主元**（pivot）。在当前列尚未使用的行中找一个非零元素；必要时交换行，把它移到当前行，再用它消去同列下方的元素。若该列在余下各行全为零，就跳过这一列，继续向右。重复到没有可用的行或列为止，得到**行阶梯形**（row echelon form）：零行位于底部，每个非零行的首个非零元位于上一行首个非零元的右侧。再把每个主元化为 1，并消去主元上方的元素，就得到**行最简形**（reduced row echelon form）。

解方程 $\boldsymbol{Ax}=\boldsymbol{b}$ 时，把右端项作为最后一列附在 $\boldsymbol{A}$ 后面，得到增广矩阵 $[\boldsymbol{A}\mid\boldsymbol{b}]$，每次对整行执行同一操作。

三种行变换分别对应交换两个等式、将等式乘以非零数、把一个等式的倍数加到另一个等式上。这些操作不改变解，而且可以撤销，所以新方程组与原方程组的解完全相同。

下面的例子中，第一列的首个元素为零，并且有一列没有主元。

示例 1.20　换行、消元与自由变量　考虑以下增广矩阵。第一列的首个元素为零，先交换前两行，再消去第三行的第一列：

$$\left[\begin{array}{ccc|c} 0 & 1 & 2 & 3 \\ 1 & 2 & 4 & 6 \\ 2 & 4 & 8 & 12 \end{array}\right] \longrightarrow \left[\begin{array}{ccc|c} 1 & 2 & 4 & 6 \\ 0 & 1 & 2 & 3 \\ 2 & 4 & 8 & 12 \end{array}\right] \longrightarrow \left[\begin{array}{ccc|c} 1 & 2 & 4 & 6 \\ 0 & 1 & 2 & 3 \\ 0 & 0 & 0 & 0 \end{array}\right].$$

这已是阶梯形。将第一行减去第二行的两倍，得到行最简形

$$\left[\begin{array}{ccc|c} 1 & 0 & 0 & 0 \\ 0 & 1 & 2 & 3 \\ 0 & 0 & 0 & 0 \end{array}\right].$$

第一、二列是主元列，第三列没有主元。令自由变量 $x_3=t$，便读出 $x_1=0$、$x_2=3-2t$；任意实数 t 都给出原方程组的一个解。最后

> 的零行表示 $0 = 0$，不增加约束。若出现系数全为零而右端非零的行，方程组就无解。

阶梯形让主元和自由变量一目了然。不过，主元的选择会影响实际数值计算的误差；第 10章求解方程时再讨论选主元和计算代价。

1.2.8 逆矩阵

逆矩阵用来撤销一次矩阵乘法。对 n 阶方阵 $\boldsymbol{A}$，若存在 n 阶方阵 $\boldsymbol{B}$ 满足

$$\boldsymbol{A}\boldsymbol{B} = \boldsymbol{B}\boldsymbol{A} = \boldsymbol{I}_n,$$

就称 $\boldsymbol{A}$ 可逆，称 $\boldsymbol{B}$ 为 $\boldsymbol{A}$ 的**逆矩阵**（inverse matrix），记作 $\boldsymbol{A}^{-1}$。

可逆矩阵给出的方程有唯一解。设 $\boldsymbol{A}$ 可逆。若 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{y}$，两边左乘 $\boldsymbol{A}^{-1}$ 得 $\boldsymbol{x} = \boldsymbol{A}^{-1}\boldsymbol{y}$，所以方程至多有一个解；反过来，$\boldsymbol{x} = \boldsymbol{A}^{-1}\boldsymbol{y}$ 满足 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{A}\boldsymbol{A}^{-1}\boldsymbol{y} = \boldsymbol{y}$。所以方程 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{y}$ 有唯一解 $\boldsymbol{x} = \boldsymbol{A}^{-1}\boldsymbol{y}$。

逆矩阵若存在则唯一。若 $\boldsymbol{B}, \boldsymbol{C}$ 都满足条件，由结合律，

$$\boldsymbol{B} = \boldsymbol{B}(\boldsymbol{A}\boldsymbol{C}) = (\boldsymbol{B}\boldsymbol{A})\boldsymbol{C} = \boldsymbol{C}.$$

因此记号 $\boldsymbol{A}^{-1}$ 没有歧义。

怎样求逆取决于矩阵的结构。下面从对角矩阵开始，再给出二阶方阵的公式和一般方阵的做法。

对角矩阵的逆　每个 $d_i \neq 0$ 时，逐个取倒数：

$$\operatorname{diag}(d_1, \dots, d_n)^{-1} = \operatorname{diag}(1/d_1, \dots, 1/d_n).$$

两个对角矩阵相乘时对角元逐个相乘，所以两侧乘积都是 $\boldsymbol{I}_n$。例如 $\operatorname{diag}(2,1)^{-1} = \operatorname{diag}(1/2, 1)$。若某个 $d_i = 0$，则 $\boldsymbol{D} = \operatorname{diag}(d_1, \dots, d_n)$ 左乘任何 $\boldsymbol{B}$，都把 $\boldsymbol{B}$ 的第 i 行乘以 0。于是 $\boldsymbol{D}\boldsymbol{B}$ 的第 i 行是零，不可能等于 $\boldsymbol{I}_n$ 的第 i 行，这时 $\boldsymbol{D}$ 不可逆。

二阶方阵的逆　$ad - bc \neq 0$ 时，

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}.$$

直接相乘即可验证两侧乘积都是 $\boldsymbol{I}_2$：例如左上元素为 $(ad-bc)/(ad-bc) = 1$，右上元素为 $(-ab + ba)/(ad - bc) = 0$。分母 $ad - bc$ 就是下一节的二阶行列式。

一般方阵的逆 一般方阵没有这样简短的公式，但可以用初等行变换计算。$\boldsymbol{A}^{-1}$ 的第 j 列 $\boldsymbol{A}^{-1}\boldsymbol{e}_j$ 正是方程 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{e}_j$ 的解，所以求逆就是解 n 个系数矩阵相同的方程。这些方程的消元步骤只由 $\boldsymbol{A}$ 决定，可以一并处理：把 $\boldsymbol{A}$ 与单位矩阵并排，得到 $[\boldsymbol{A}\mid\boldsymbol{I}_n]$，对整个增广矩阵作行变换。

为什么最后右侧就是逆矩阵？若左侧最终化为 $\boldsymbol{I}_n$，各步初等矩阵的乘积记为 $\boldsymbol{E}$，它是可逆矩阵，并满足 $\boldsymbol{E}\boldsymbol{A}=\boldsymbol{I}_n$；右侧则变为 $\boldsymbol{E}\boldsymbol{I}_n=\boldsymbol{E}$。由 $\boldsymbol{E}$ 可逆得 $\boldsymbol{A}=\boldsymbol{E}^{-1}$，从而 $\boldsymbol{A}\boldsymbol{E}=\boldsymbol{I}_n$。所以右侧的 $\boldsymbol{E}$ 就是 $\boldsymbol{A}^{-1}$：

$$[\boldsymbol{A}\mid\boldsymbol{I}_n]\longrightarrow[\boldsymbol{I}_n\mid\boldsymbol{A}^{-1}].$$

下面对一个三阶方阵逐步计算。

示例 1.21　用初等行变换求逆　求

$$\boldsymbol{A}=\begin{bmatrix}1&2&1\\0&1&1\\1&2&2\end{bmatrix}$$

的逆。把 $\boldsymbol{A}$ 与 $\boldsymbol{I}_3$ 并排以后，先把第三行减去第一行，左侧成为主元都为 1 的上三角矩阵。再自下而上消去主元上方的元素：把第一、二行分别减去第三行，最后把第一行减去第二行的两倍。

$$\left[\begin{array}{ccc|ccc}1&2&1&1&0&0\\0&1&1&0&1&0\\1&2&2&0&0&1\end{array}\right]$$

$$\longrightarrow\left[\begin{array}{ccc|ccc}1&2&1&1&0&0\\0&1&1&0&1&0\\0&0&1&-1&0&1\end{array}\right]$$

$$\longrightarrow\left[\begin{array}{ccc|ccc}1&2&0&2&0&-1\\0&1&0&1&1&-1\\0&0&1&-1&0&1\end{array}\right]$$

$$\longrightarrow\left[\begin{array}{ccc|ccc}1&0&0&0&-2&1\\0&1&0&1&1&-1\\0&0&1&-1&0&1\end{array}\right].$$

左侧已化为 $\boldsymbol{I}_3$，所以

$$\boldsymbol{A}^{-1}=\begin{bmatrix}0&-2&1\\1&1&-1\\-1&0&1\end{bmatrix}.$$

可以相乘核对。例如 $\boldsymbol{A}$ 的第一行与 $\boldsymbol{A}^{-1}$ 的第一列相乘得 $1\cdot 0+2\cdot 1+1\cdot(-1)=1$，与第二列相乘得 $1\cdot(-2)+2\cdot 1+1\cdot 0=0$；其余七个位置照此计算，合起来正是 $\boldsymbol{A}\boldsymbol{A}^{-1}=\boldsymbol{I}_3$。

注意 $\boldsymbol{A}_{1,1}=1$，而 $(\boldsymbol{A}^{-1})_{1,1}=0$。一般矩阵把各个坐标掺在一起，逆矩阵要作为整体求出，不能像对角矩阵那样逐个元素取倒数。

如果化简时某一列找不到主元，左侧会出现零行，不能化为 $\boldsymbol{I}_n$；由于所有行变换都可逆，这样的矩阵没有逆。

这种计算实质上是在解线性方程组。只求一个方程的解时，通常直接对右端项消元，不必先求出整个逆矩阵。方阵何时可逆、方程的解集怎样刻画，在第 9章系统处理；怎样经济而稳定地求解，在第 10章讨论。

单侧逆　矩形矩阵没有双侧的逆，但可能从一侧抵消。对 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$，满足 $\boldsymbol{L}\boldsymbol{A}=\boldsymbol{I}_d$ 的 $\boldsymbol{L}\in\mathbb{R}^{d\times m}$ 称为左逆，满足 $\boldsymbol{A}\boldsymbol{R}=\boldsymbol{I}_m$ 的 $\boldsymbol{R}\in\mathbb{R}^{d\times m}$ 称为右逆。

两种单侧逆对方程 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{y}$ 的作用不同。有左逆时，若方程有解，两边左乘 $\boldsymbol{L}$ 得 $\boldsymbol{x}=\boldsymbol{L}\boldsymbol{y}$，所以解只能是 $\boldsymbol{L}\boldsymbol{y}$。有右逆时，$\boldsymbol{A}(\boldsymbol{R}\boldsymbol{y})=\boldsymbol{I}_m\boldsymbol{y}=\boldsymbol{y}$，所以 $\boldsymbol{x}=\boldsymbol{R}\boldsymbol{y}$ 总是一个解。

与方阵的逆不同，单侧逆一般不唯一。

示例 1.22　反例：左逆不唯一　取 $\boldsymbol{A}=(1,0)^{\mathsf{T}}\in\mathbb{R}^{2\times 1}$。对任意实数 c，令 $\boldsymbol{L}=(1,c)\in\mathbb{R}^{1\times 2}$，则

$$\boldsymbol{L}\boldsymbol{A}=1\cdot 1+c\cdot 0=1=\boldsymbol{I}_1.$$

$\boldsymbol{A}$ 的第二个坐标是零，$\boldsymbol{L}$ 的第二个元素无论取什么都不影响乘积。于是每个 c 都给出一个左逆，$\boldsymbol{A}$ 的左逆有无穷多个。

回到方阵。下面几条规则说明，可逆方阵经过乘积、求逆、数乘和转置以后仍然可逆，并给出逆矩阵的表达式。设 $\boldsymbol{A},\boldsymbol{B}$ 都是 n 阶可逆方阵。

乘积的逆　两个可逆方阵的乘积仍然可逆，它的逆是两个因子的逆按相反次序相乘。

定理 1.23　乘积的逆　设 $\boldsymbol{A},\boldsymbol{B}$ 都是 n 阶可逆方阵，则 $\boldsymbol{A}\boldsymbol{B}$ 可逆，且

$$(\boldsymbol{A}\boldsymbol{B})^{-1}=\boldsymbol{B}^{-1}\boldsymbol{A}^{-1}. \tag{1.9}$$

证明 由矩阵乘法的结合律，

$$(\boldsymbol{AB})(\boldsymbol{B}^{-1}\boldsymbol{A}^{-1}) = \boldsymbol{A}(\boldsymbol{B}\boldsymbol{B}^{-1})\boldsymbol{A}^{-1} = \boldsymbol{A}\boldsymbol{A}^{-1} = \boldsymbol{I}_n,$$
$$(\boldsymbol{B}^{-1}\boldsymbol{A}^{-1})(\boldsymbol{AB}) = \boldsymbol{B}^{-1}(\boldsymbol{A}^{-1}\boldsymbol{A})\boldsymbol{B} = \boldsymbol{B}^{-1}\boldsymbol{B} = \boldsymbol{I}_n.$$

按逆矩阵的定义，$\boldsymbol{B}^{-1}\boldsymbol{A}^{-1}$ 是 $\boldsymbol{AB}$ 的逆；由逆矩阵的唯一性，式 (1.9)成立。 ■

次序反转是因为 $\boldsymbol{ABx}$ 先作用 $\boldsymbol{B}$、再作用 $\boldsymbol{A}$，撤销时要先撤销后作用的 $\boldsymbol{A}$，再撤销 $\boldsymbol{B}$。

逆的逆

$$(\boldsymbol{A}^{-1})^{-1} = \boldsymbol{A}.$$

在定义中，$\boldsymbol{A}$ 与 $\boldsymbol{A}^{-1}$ 的地位对称：$\boldsymbol{A}^{-1}\boldsymbol{A} = \boldsymbol{A}\boldsymbol{A}^{-1} = \boldsymbol{I}_n$ 同样说明 $\boldsymbol{A}$ 是 $\boldsymbol{A}^{-1}$ 的逆。

数乘的逆

$$(c\boldsymbol{A})^{-1} = c^{-1}\boldsymbol{A}^{-1} \qquad (c \neq 0).$$

直接相乘：$(c\boldsymbol{A})(c^{-1}\boldsymbol{A}^{-1}) = (cc^{-1})\boldsymbol{A}\boldsymbol{A}^{-1} = \boldsymbol{I}_n$，反方向同理。

转置的逆

$$(\boldsymbol{A}^{\top})^{-1} = (\boldsymbol{A}^{-1})^{\top}.$$

由乘积的转置，$\boldsymbol{A}^{\top}(\boldsymbol{A}^{-1})^{\top} = (\boldsymbol{A}^{-1}\boldsymbol{A})^{\top} = \boldsymbol{I}^{\top} = \boldsymbol{I}$，反方向同理，所以 $(\boldsymbol{A}^{-1})^{\top}$ 就是 $\boldsymbol{A}^{\top}$ 的逆。

1.2.9 矩阵的幂

同一个方阵反复作用，就得到矩阵的幂。对 d 阶方阵 $\boldsymbol{A}$，$\boldsymbol{A}^k$ 定义为 k 个 $\boldsymbol{A}$ 连乘（$k \geq 1$），并规定 $\boldsymbol{A}^0 = \boldsymbol{I}_d$。$\boldsymbol{A}$ 可逆时，再定义负幂 $\boldsymbol{A}^{-k} = (\boldsymbol{A}^{-1})^k$。非方阵不能与自身相乘，所以没有矩阵幂。

矩阵的幂是反复的矩阵乘法，不是逐元素乘方。下面的例子说明两者的差别。

示例 1.24 矩阵的平方不是逐元素平方 取

$$\boldsymbol{A} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix},$$

按矩阵乘法计算它的平方：

$$\boldsymbol{A}^2=\begin{pmatrix}1&1\\0&1\end{pmatrix}\begin{pmatrix}1&1\\0&1\end{pmatrix}=\begin{pmatrix}1\cdot1+1\cdot0&1\cdot1+1\cdot1\\0\cdot1+1\cdot0&0\cdot1+1\cdot1\end{pmatrix}=\begin{pmatrix}1&2\\0&1\end{pmatrix}.$$

右上角的元素变为 2，逐元素平方却只会得到 $1^2=1$。差别在于 $\boldsymbol{A}^2$ 的右上角是第一行与第二列的内积 $1\cdot1+1\cdot1$，同时用到了两个元素。继续相乘，右上角每次增加 1。

有两类矩阵由幂的关系刻画。满足 $\boldsymbol{A}^2=\boldsymbol{A}$ 的方阵称为**幂等**（idempotent）矩阵，它作用一次与作用多次效果相同。存在正整数 s 使 $\boldsymbol{N}^s=\boldsymbol{0}$ 的方阵称为**幂零**（nilpotent）矩阵。下面各举一例。

示例 1.25　幂等矩阵与幂零矩阵　看两个二阶矩阵

$$\boldsymbol{P}=\operatorname{diag}(1,0),\qquad \boldsymbol{N}=\begin{pmatrix}0&1\\0&0\end{pmatrix}$$

对 $\boldsymbol{u}\in\mathbb{R}^2$ 的作用。$\boldsymbol{P}\boldsymbol{u}=(u_1,0)^{\top}$ 只保留第一个坐标；$(u_1,0)^{\top}$ 再经过 $\boldsymbol{P}$，第一个坐标照样保留，第二个坐标本来就是零，结果不变，所以 $\boldsymbol{P}^2=\boldsymbol{P}$。$\boldsymbol{N}\boldsymbol{u}=(u_2,0)^{\top}$ 把第二个坐标移到第一个位置，并把第二个位置清零；再作用一次时，$\boldsymbol{N}$ 丢掉第一个坐标 u_2，而第二个坐标已是零，得 $\boldsymbol{N}(u_2,0)^{\top}=(0,0)^{\top}$。直接相乘也得到

$$\boldsymbol{N}^2=\begin{pmatrix}0&1\\0&0\end{pmatrix}\begin{pmatrix}0&1\\0&0\end{pmatrix}=\begin{pmatrix}0&0\\0&0\end{pmatrix}.$$

所以 $\boldsymbol{P}$ 是幂等矩阵；$\boldsymbol{N}$ 本身不是零矩阵，平方却为零，是幂零矩阵。

1.2.9.1 幂的性质

同一矩阵的幂按结合律满足与实数幂相同的指数法则。设 $\boldsymbol{A}$ 为方阵，m,n 为非负整数；$\boldsymbol{A}$ 可逆时，m,n 可取任意整数。

同底幂相乘

$$\boldsymbol{A}^m\boldsymbol{A}^n=\boldsymbol{A}^{m+n}.$$

由结合律，两边都是同样个数的 $\boldsymbol{A}$（或 $\boldsymbol{A}^{-1}$）连乘；指数异号时，相邻的 $\boldsymbol{A}\boldsymbol{A}^{-1}$ 逐对消去。交换 m,n 可见，同一矩阵的不同次幂彼此可以交换。不同矩阵则不一定交换，因此

$$(\boldsymbol{A}+\boldsymbol{B})^2=\boldsymbol{A}^2+\boldsymbol{A}\boldsymbol{B}+\boldsymbol{B}\boldsymbol{A}+\boldsymbol{B}^2,$$

只有 $\boldsymbol{AB}=\boldsymbol{BA}$ 时，才能把中间两项合成 $2\boldsymbol{AB}$。这与标量平方公式的差别来自乘法的次序。

幂的幂

$$(\boldsymbol{A}^m)^n=\boldsymbol{A}^{mn}.$$

左边是 n 组、每组 m 个因子的连乘，由结合律去掉括号即得。

负幂与逆相容

$$(\boldsymbol{A}^k)^{-1}=(\boldsymbol{A}^{-1})^k=\boldsymbol{A}^{-k}.$$

对 k 个相同因子反复使用式 (1.9)即得。

1.3 行列式、迹与元素内积

上一节的运算大多把矩阵变成另一个矩阵。本节讨论三种把矩阵变成一个数的运算：行列式衡量方阵对有向体积的缩放，迹累加主对角元素，Frobenius 内积把两个同形矩阵的对应元素配对。三者回答的问题不同，单凭其中一个数也无法恢复原矩阵。

1.3.1 行列式

行列式把一个方阵变成一个数。本小节先给出计算公式，再说明这个数度量有向体积的缩放，然后整理它的性质，最后用代数余子式构造古典伴随，并证明方阵的单侧逆就是逆。

1.3.1.1 行列式的定义

行列式的公式是对全部排列求和，所以先规定排列的符号。$\{1,\dots,d\}$ 到自身的双射称为排列，全体排列记为 S_d，共 $d!$ 个。对排列 π，满足 $i<j$ 而 $\pi(i)>\pi(j)$ 的索引对 (i,j) 称为逆序对，逆序对的个数记为 $N(\pi)$。π 的符号定义为 $\operatorname{sgn}(\pi)=(-1)^{N(\pi)}$。

定义 1.26　行列式　d 阶方阵 $\boldsymbol{A}=(a_{i,j})$ 的**行列式**（determinant）为

$$\det\boldsymbol{A}=\sum_{\pi\in S_d}\operatorname{sgn}(\pi)\prod_{i=1}^{d}a_{i,\pi(i)}.$$

每个排列 π 规定第 i 行取第 $\pi(i)$ 列的元素。于是每一项从每行各取一个元素，各列也恰好各取一次；把取出的 d 个数相乘，按逆序对数的奇偶配上正负号，再对全部排列求和。可见行列式是矩阵元素的多项式。

同一个和也可以按列书写。把每项的乘积按列号重排，得 $\prod_i a_{i,\pi(i)} = \prod_j a_{\pi^{-1}(j),j}$。$\pi$ 的逆序对 (i,j) 与 π^{-1} 的逆序对 $(\pi(j),\pi(i))$ 一一对应，所以 $\operatorname{sgn}(\pi^{-1}) = \operatorname{sgn}(\pi)$。$\pi$ 遍历 S_d 时，$\sigma = \pi^{-1}$ 也遍历 S_d，于是

$$\det \boldsymbol{A} = \sum_{\sigma \in S_d} \operatorname{sgn}(\sigma) \prod_{j=1}^{d} a_{\sigma(j),j}. \tag{1.10}$$

二阶时只有两个排列。恒等排列没有逆序对，取正号；交换 $1,2$ 的排列有一个逆序对，取负号。于是

$$\det \begin{pmatrix} a & b \\ c & d \end{pmatrix} = ad - bc,$$

例如

$$\det \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} = 1 \cdot 4 - 2 \cdot 3 = -2.$$

三阶时有六个排列。恒等排列与两个循环排列 $(\pi(1),\pi(2),\pi(3)) = (2,3,1)$、$(3,1,2)$ 的逆序对数为 0 或 2，取正号；只交换两个位置的三个排列 $(1,3,2)$、$(2,1,3)$、$(3,2,1)$ 的逆序对数为 1 或 3，取负号。于是

$$\begin{aligned} \det \boldsymbol{A} = {} & a_{1,1}a_{2,2}a_{3,3} + a_{1,2}a_{2,3}a_{3,1} + a_{1,3}a_{2,1}a_{3,2} \\ & - a_{1,1}a_{2,3}a_{3,2} - a_{1,2}a_{2,1}a_{3,3} - a_{1,3}a_{2,2}a_{3,1}. \end{aligned}$$

下面用这个公式计算一个具体的三阶行列式。

示例 1.27　三阶行列式的排列展开　取

$$\boldsymbol{A} = \begin{pmatrix} 2 & 0 & 1 \\ 1 & 3 & 0 \\ 0 & 1 & 1 \end{pmatrix},$$

按上式的六项次序代入元素：

$$\begin{aligned} \det \boldsymbol{A} &= 2 \cdot 3 \cdot 1 + 0 \cdot 0 \cdot 0 + 1 \cdot 1 \cdot 1 - 2 \cdot 0 \cdot 1 - 0 \cdot 1 \cdot 1 - 1 \cdot 3 \cdot 0 \\ &= 6 + 0 + 1 - 0 - 0 - 0 = 7. \end{aligned}$$

所以 $\det \boldsymbol{A} = 7$。六项中只有两项非零，其余四项都至少取到一个零元素。矩阵中的零越多，排列展开中需要真正计算的项就越少。

高阶时排列有 $d!$ 个，直接展开很费力；实际计算通常借助后面的性质和消元。

1.3.1.2 行列式的几何意义

排列公式本身看不出行列式度量什么。本小节从平行四边形的面积和平行六面体的体积出发，只用它们满足的几条几何规则，推出同一个公式。

有向面积 平面上两个向量 $\boldsymbol{u},\boldsymbol{v}$ 张成一个平行四边形。给它的面积配上符号：从 $\boldsymbol{u}$ 逆时针转到 $\boldsymbol{v}$（转角小于 π）时取正，顺时针时取负。记这个**有向面积**为 $S(\boldsymbol{u},\boldsymbol{v})$。它满足三条规则。

- 对每条边线性：以 $\boldsymbol{v}$ 为底，面积等于底长乘以 $\boldsymbol{u}$ 在 $\boldsymbol{v}$ 的法方向上的有向高；有向高是 $\boldsymbol{u}$ 在一个单位法向量上的分量，对 $\boldsymbol{u}$ 线性。所以

$$S(a\boldsymbol{u}+b\boldsymbol{w},\boldsymbol{v}) = aS(\boldsymbol{u},\boldsymbol{v}) + bS(\boldsymbol{w},\boldsymbol{v}),$$

  对第二条边同理。
- 交换两边变号：交换 $\boldsymbol{u},\boldsymbol{v}$，转向反过来，面积不变，即 $S(\boldsymbol{v},\boldsymbol{u}) = -S(\boldsymbol{u},\boldsymbol{v})$。特别地，$S(\boldsymbol{u},\boldsymbol{u}) = 0$，共线的两条边张成退化的平行四边形。
- 单位正方形的面积为 1：$S(\boldsymbol{e}_1,\boldsymbol{e}_2) = 1$。

把 $\boldsymbol{u} = u_1\boldsymbol{e}_1 + u_2\boldsymbol{e}_2$、$\boldsymbol{v} = v_1\boldsymbol{e}_1 + v_2\boldsymbol{e}_2$ 代入，按第一条规则展开成四项，再用后两条规则，

$$\begin{aligned} S(\boldsymbol{u},\boldsymbol{v}) &= u_1v_1\underbrace{S(\boldsymbol{e}_1,\boldsymbol{e}_1)}_{0} + u_1v_2\underbrace{S(\boldsymbol{e}_1,\boldsymbol{e}_2)}_{1} + u_2v_1\underbrace{S(\boldsymbol{e}_2,\boldsymbol{e}_1)}_{-1} + u_2v_2\underbrace{S(\boldsymbol{e}_2,\boldsymbol{e}_2)}_{0} \\ &= u_1v_2 - u_2v_1. \end{aligned}$$

这正是以 $\boldsymbol{u},\boldsymbol{v}$ 为列的二阶行列式。下面用三组向量观察有向面积的数值与符号。

示例 1.28 平面上的有向面积 取 $\boldsymbol{u} = (1,0)^{\mathsf{T}}$ 与 $\boldsymbol{v} = (1,1)^{\mathsf{T}}$，先按 $(\boldsymbol{u},\boldsymbol{v})$ 的次序计算，再交换成 $(\boldsymbol{v},\boldsymbol{u})$；最后换成一对共线向量 $(1,1)^{\mathsf{T}}$ 与 $(2,2)^{\mathsf{T}}$。按公式 $u_1v_2 - u_2v_1$，三组依次得到

$$1\cdot 1 - 0\cdot 1 = 1,$$

$$1\cdot 0 - 1\cdot 1 = -1,$$

$$1\cdot 2 - 1\cdot 2 = 0.$$

第一组张成底为 1、高为 1 的平行四边形，从 $\boldsymbol{u}$ 逆时针转到 $\boldsymbol{v}$，有向面积为 1。交换次序后，平行四边形没有变，转向却反了过来，所以只有符号变负。共线的两个向量张成的平行四边形退化成线段，有向面积为 0。

有向体积　空间中三个向量 $\boldsymbol{u},\boldsymbol{v},\boldsymbol{w}$ 张成一个平行六面体。按右手系取正、左手系取负，得到**有向体积**$V(\boldsymbol{u},\boldsymbol{v},\boldsymbol{w})$。理由与平面相同：以 $\boldsymbol{v},\boldsymbol{w}$ 张成的面为底，体积等于底面积乘以 $\boldsymbol{u}$ 的有向高，所以 V 对 $\boldsymbol{u}$ 线性，对其余两条棱同理；交换任意两条棱，右手系变为左手系，V 变号；单位立方体 $V(\boldsymbol{e}_1,\boldsymbol{e}_2,\boldsymbol{e}_3)=1$。

把三条棱都按坐标展开，共得 $3^3=27$ 项，每项形如 $u_i v_j w_k\, V(\boldsymbol{e}_i,\boldsymbol{e}_j,\boldsymbol{e}_k)$。$i,j,k$ 中有两个相同时，交换这两个相同的向量不改变 V，却又使它变号，所以这一项为零。

留下的六项中 (i,j,k) 是 $(1,2,3)$ 的排列 σ。把 $\boldsymbol{e}_{\sigma(1)},\boldsymbol{e}_{\sigma(2)},\boldsymbol{e}_{\sigma(3)}$ 排回原来的次序时，每交换一对相邻且次序颠倒的向量，逆序对数恰好减少 1，所以恰好交换 $N(\sigma)$ 次，$V(\boldsymbol{e}_{\sigma(1)},\boldsymbol{e}_{\sigma(2)},\boldsymbol{e}_{\sigma(3)})=\operatorname{sgn}(\sigma)$。于是

$$V(\boldsymbol{u},\boldsymbol{v},\boldsymbol{w})=\sum_{\sigma\in S_3}\operatorname{sgn}(\sigma)\,u_{\sigma(1)}v_{\sigma(2)}w_{\sigma(3)},$$

即式 (1.10)在 $d=3$ 时的形式：$V(\boldsymbol{u},\boldsymbol{v},\boldsymbol{w})=\det[\boldsymbol{u}\ \boldsymbol{v}\ \boldsymbol{w}]$。

一般维数　上面的展开只用到两条规则：对每个向量线性，交换两个向量变号。d 维时照样展开，得到下面的结论：设 D 把 d 个 $\mathbb{R}^d$ 中的向量映成一个数，对每个向量线性，并且交换任意两个向量时变号，则

$$D(\boldsymbol{a}_1,\dots,\boldsymbol{a}_d)=D(\boldsymbol{e}_1,\dots,\boldsymbol{e}_d)\,\det\begin{bmatrix}\boldsymbol{a}_1 & \cdots & \boldsymbol{a}_d\end{bmatrix}. \tag{1.11}$$

反过来也可以直接验证，排列公式作为各列的函数确实满足这两条规则：它对每列线性；交换两列相当于把每个排列复合一次对换，逆序对数的奇偶随之改变。所以行列式就是满足两条规则、并在单位矩阵处取值 1 的那个函数。

把 d 维平行多面体的有向体积取作 D，单位立方体的体积为 1，代入 $\boldsymbol{a}_j=\boldsymbol{A}\boldsymbol{e}_j$，得到：$\det\boldsymbol{A}$ 是 $\boldsymbol{A}$ 的各列张成的平行多面体的有向体积。$\boldsymbol{A}$ 把单位立方体映成这个平行多面体，所以 $\det\boldsymbol{A}$ 是 $\boldsymbol{A}$ 作用下有向体积的放大倍数：绝对值是体积之比，符号表示定向是否翻转。图 1.2画出了平面上的这种缩放。

1.3.1.3　行列式的性质

上一小节表明，行列式是各列张成的有向体积。下面的前两条性质就是有向体积的两条规则，其余性质由它们和排列公式推出。设 $\boldsymbol{A},\boldsymbol{B}$ 为 d 阶方阵。

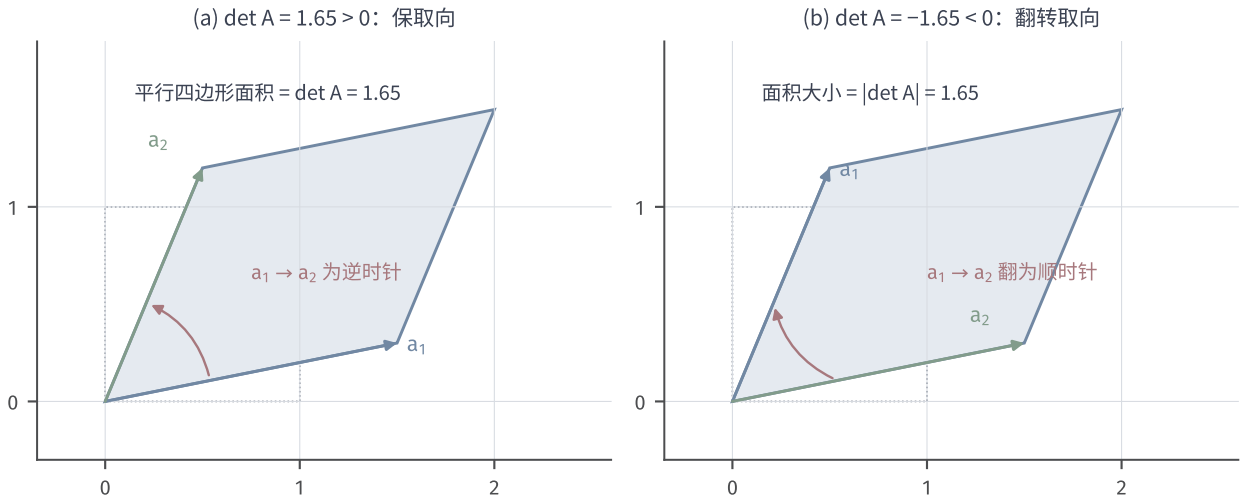


图 1.2　行列式作为有向体积的缩放。左：单位正方形由 $\boldsymbol{e}_1=(1,0)$、$\boldsymbol{e}_2=(0,1)$ 张成，面积为 1。中：$\boldsymbol{A}=\left(\begin{smallmatrix}2 & 0.5\\ 0 & 1.5\end{smallmatrix}\right)$ 把它映成由 $\boldsymbol{A}\boldsymbol{e}_1=(2,0)$、$\boldsymbol{A}\boldsymbol{e}_2=(0.5,1.5)$ 张成的平行四边形，有向面积为 $2\cdot 1.5-0.5\cdot 0=3=\det\boldsymbol{A}>0$（保定向）。右：$\boldsymbol{A}$ 把 $\boldsymbol{e}_1$ 反射到 $(-2,0)$，有向面积为 -3（反定向）。向量与数值均为解析教学例。

对列的多线性　三个矩阵只在同一列上不同、其余各列相同时，

$$\det\begin{bmatrix}\cdots & a\boldsymbol{u}+b\boldsymbol{w} & \cdots\end{bmatrix}=a\det\begin{bmatrix}\cdots & \boldsymbol{u} & \cdots\end{bmatrix}+b\det\begin{bmatrix}\cdots & \boldsymbol{w} & \cdots\end{bmatrix}.$$

交替性　交换两列，行列式变号；两列相同，行列式为零。前者是有向体积的规则，也已由排列公式验证。后者是因为交换两个相同的列不改变矩阵，行列式却要变号。

由多线性和交替性还能得到两个常用结论。第一，把某列的倍数加到另一列上，行列式不变：按多线性拆开后，多出的一项有两列相同，等于零。第二，某一列是其余各列的线性组合时，行列式为零：把这一列按组合展开，每一项都有两列相同。例如第二列是第一列的 2 倍时，

$$\det\begin{pmatrix}1 & 2\\ 2 & 4\end{pmatrix}=4-4=0.$$

行变换与可逆性　列上的这两条规则对行同样成立。排列公式的每一项从每行恰取一个元素，所以行列式对每一行也是线性的。交换第 i,k 两行，相当于把每个 π 与交换 i,k 的对换复合，逆序对数的奇偶随之改变，所以行列式变号。于是三种初等行变换对行列式的影响为：

交换两行：	行列式变号；
某行乘以非零数c：	行列式乘以c；
某行加上另一行的倍数：	行列式不变。

每一步消元都只使行列式乘以一个非零数，所以消元前后行列式是否为零不变。若某列找不到主元，阶梯形至少有一行全零；由对这一行的线性，行列式为零，矩阵也无法化为单位矩阵。若每列都找到主元，继续消元可以化为单位矩阵，而排列公式中 $\det \boldsymbol{I}$ 只剩恒等排列一项，等于 1，所以原矩阵的行列式非零，并且可以用第 1.2.8节的增广矩阵方法求逆。因此

$$\boldsymbol{A}\text{可逆} \iff \det \boldsymbol{A} \neq 0.$$

转置

$$\det(\boldsymbol{A}^{\top}) = \det \boldsymbol{A}.$$

$\boldsymbol{A}^{\top}$ 的排列公式为 $\sum_{\sigma} \operatorname{sgn}(\sigma) \prod_{j} (\boldsymbol{A}^{\top})_{j,\sigma(j)} = \sum_{\sigma} \operatorname{sgn}(\sigma) \prod_{j} a_{\sigma(j),j}$，这正是式 (1.10)。行列式对行和对列的性质因此完全对称。

数乘与加法

$$\det(c\boldsymbol{A}) = c^{d} \det \boldsymbol{A},$$

$$\det(\boldsymbol{A} + \boldsymbol{B}) \neq \det \boldsymbol{A} + \det \boldsymbol{B} \text{ (一般)}.$$

数乘把 d 列各乘以 c，由对每列的线性，提出 d 个 c。行列式只对每一列分别线性，对整个矩阵却不是线性的。下面是一个反例。

> **示例 1.29　反例：行列式不保持加法**　最简单的情形就足以说明问题。取 $\boldsymbol{A} = \boldsymbol{B} = \boldsymbol{I}_2$，则 $\det \boldsymbol{A} + \det \boldsymbol{B} = 1 + 1 = 2$；而 $\boldsymbol{A} + \boldsymbol{B} = 2\boldsymbol{I}_2$，由上面的数乘公式，$\det(2\boldsymbol{I}_2) = 2^2 \det \boldsymbol{I}_2 = 4$。两者不等。原因在于两列同时加倍，体积要乘两次 2。

乘法性

$$\det(\boldsymbol{AB}) = \det \boldsymbol{A} \, \det \boldsymbol{B}.$$

从几何上看，接连作用两次，体积的放大倍数应当相乘。证明如下。固定 $\boldsymbol{A}$，把 $\det(\boldsymbol{AB})$ 看作 $\boldsymbol{B}$ 的各列 $\boldsymbol{b}_1, \dots, \boldsymbol{b}_d$ 的函数

$$D(\boldsymbol{b}_1, \dots, \boldsymbol{b}_d) = \det \begin{bmatrix} \boldsymbol{A}\boldsymbol{b}_1 & \cdots & \boldsymbol{A}\boldsymbol{b}_d \end{bmatrix} = \det(\boldsymbol{AB}).$$

$\boldsymbol{A}\boldsymbol{b}_j$ 对 $\boldsymbol{b}_j$ 线性，行列式对每列线性，所以 D 对每个 $\boldsymbol{b}_j$ 线性；交换 $\boldsymbol{b}_j, \boldsymbol{b}_k$ 就是交换 $\boldsymbol{AB}$ 的两列，D 变号。由式 (1.11)，

$$\det(\boldsymbol{AB}) = D(\boldsymbol{e}_1, \dots, \boldsymbol{e}_d) \det \boldsymbol{B} = \det \boldsymbol{A} \, \det \boldsymbol{B}.$$

矩阵乘法不可交换，但 $\det(\boldsymbol{AB}) = \det(\boldsymbol{BA})$ 总成立，因为两边都等于 $\det \boldsymbol{A} \, \det \boldsymbol{B}$。

三角矩阵的行列式

$$\det \boldsymbol{A} = a_{1,1}a_{2,2}\cdots a_{d,d} \qquad (\boldsymbol{A}\text{为上三角或下三角矩阵}).$$

设 $\boldsymbol{A}$ 为上三角矩阵。若排列 π 不是恒等排列，必有某行 i 满足 $\pi(i) < i$，因为 $\sum_i(\pi(i) - i) = 0$ 而各项不全为零。这一行取到主对角线下方的零元素，所以这一项为零，排列公式中只剩恒等排列一项。下三角时同理。例如

$$\det \begin{pmatrix} 1 & 2 & 3 \\ 0 & 4 & 5 \\ 0 & 0 & 6 \end{pmatrix} = 1 \cdot 4 \cdot 6 = 24.$$

特别地，$\det \operatorname{diag}(d_1, \dots, d_d) = d_1 \cdots d_d$。由乘法性，两个上三角矩阵乘积的行列式等于两者全部对角元之积，这与三角矩阵乘积的对角元逐个相乘一致。

结合行变换的规则，可以用消元计算行列式：先把方阵化为上三角矩阵，取对角元素的乘积，再补偿换行和倍乘的影响。例如

$$\det \begin{pmatrix} 0 & 1 & 2 \\ 1 & 2 & 1 \\ 2 & 7 & 4 \end{pmatrix} = -\det \begin{pmatrix} 1 & 2 & 1 \\ 0 & 1 & 2 \\ 0 & 3 & 2 \end{pmatrix} = -\det \begin{pmatrix} 1 & 2 & 1 \\ 0 & 1 & 2 \\ 0 & 0 & -4 \end{pmatrix} = 4.$$

第一步交换前两行，并从第三行减去第一行的两倍；第二步从第三行减去第二行的三倍。交换行改变符号，两次加倍数不改变行列式。

1.3.1.4 代数余子式与古典伴随

排列公式有 $d!$ 项。按某一行分组，可以把它化为 d 个 $d-1$ 阶行列式。把这些低阶行列式排成矩阵，又能得到一个与 $\boldsymbol{A}$ 相乘等于 $(\det \boldsymbol{A})\boldsymbol{I}_d$ 的矩阵。

按行（列）展开 设 $d \geq 2$。删除第 i 行、第 j 列，得到的 $(d-1)$ 阶子矩阵记为 $\boldsymbol{A}^{(i,j)}$。定义**代数余子式**（cofactor）

$$C_{i,j} = (-1)^{i+j} \det \boldsymbol{A}^{(i,j)}.$$

则对任一行 i 与任一列 j，

$$\det \boldsymbol{A} = \sum_{j=1}^{d} a_{i,j}C_{i,j} = \sum_{i=1}^{d} a_{i,j}C_{i,j}.$$

把排列公式按第 i 行所取的列分类，取第 j 列的各项之和正是 $a_{i,j}C_{i,j}$；按列展开同理。下面沿第一行展开示例 1.27中的矩阵，与排列公式的结果对照。

示例 1.30　沿第一行展开三阶行列式　仍取

$$\boldsymbol{A} = \begin{pmatrix} 2 & 0 & 1 \\ 1 & 3 & 0 \\ 0 & 1 & 1 \end{pmatrix}.$$

第一行元素为 $2, 0, 1$，对应代数余子式的符号 $(-1)^{1+j}$ 依次为 $+, -, +$。每个元素乘以删去它所在行、列后剩下的二阶行列式：

$$\begin{aligned} \det \boldsymbol{A} &= 2 \cdot \det \begin{pmatrix} 3 & 0 \\ 1 & 1 \end{pmatrix} - 0 \cdot \det \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} + 1 \cdot \det \begin{pmatrix} 1 & 3 \\ 0 & 1 \end{pmatrix} \\ &= 2 \cdot 3 - 0 \cdot 1 + 1 \cdot 1 = 7. \end{aligned}$$

结果与示例 1.27的排列展开一致。第一行的 0 使中间一项不必计算，所以按零较多的行或列展开最省事。

古典伴随恒等式　把全部代数余子式排成矩阵 $\boldsymbol{C}$，其转置 $\operatorname{adj}(\boldsymbol{A}) = \boldsymbol{C}^{\top}$ 称为**古典伴随**（classical adjugate）。

定理 1.31　古典伴随恒等式　对任意 d 阶方阵 $\boldsymbol{A}$，

$$\boldsymbol{A}\,\operatorname{adj}(\boldsymbol{A}) = \operatorname{adj}(\boldsymbol{A})\,\boldsymbol{A} = (\det \boldsymbol{A})\,\boldsymbol{I}_d.$$

证明　乘积 $\boldsymbol{A}\boldsymbol{C}^{\top}$ 的 (i,k) 元素为 $\sum_{j} a_{i,j} C_{k,j}$。当 $i = k$ 时，这正是沿第 i 行展开的 $\det \boldsymbol{A}$。当 $i \neq k$ 时，$C_{k,j}$ 不涉及第 k 行的元素，所以这个和是把第 k 行换成第 i 行后所得矩阵沿第 k 行的展开；新矩阵有两行相同，行列式为零。于是 $\boldsymbol{A}\boldsymbol{C}^{\top} = (\det \boldsymbol{A})\boldsymbol{I}_d$。按列展开，同样得到 $\boldsymbol{C}^{\top}\boldsymbol{A} = (\det \boldsymbol{A})\boldsymbol{I}_d$。 ∎

二阶时

$$\operatorname{adj} \begin{pmatrix} a & b \\ c & d \end{pmatrix} = \begin{pmatrix} d & -b \\ -c & a \end{pmatrix},$$

恒等式两边除以 $ad - bc$，就是第 1.2.8节的二阶求逆公式。

古典伴随是由余子式得到的代数构造，与第 3.6节由内积定义的伴随不是同一个对象。高阶时展开余子式的代价是阶乘级的，所以这个恒等式主要用作证明工具。下面用它证明方阵的单侧逆即逆；后文还用它给出线性方程的可逆判据（第 9.1节），并证明 Cayley–Hamilton 定理（第 4.1.3节）。

方阵的单侧逆即逆 第 1.2.8节定义逆矩阵时，要求两侧乘积都等于单位矩阵。对方阵，一侧就够了。

定理 1.32 方阵的单侧逆即逆 设 $\boldsymbol{A},\boldsymbol{B}$ 为 n 阶方阵。若 $\boldsymbol{BA}=\boldsymbol{I}_n$ 或 $\boldsymbol{AB}=\boldsymbol{I}_n$，则 $\boldsymbol{A}$ 可逆且 $\boldsymbol{B}=\boldsymbol{A}^{-1}$。

证明 由乘法性，两种情形都有 $\det\boldsymbol{A}\det\boldsymbol{B}=\det\boldsymbol{I}_n=1$，所以 $\det\boldsymbol{A}\neq 0$。令 $\boldsymbol{C}=\operatorname{adj}(\boldsymbol{A})/\det\boldsymbol{A}$，由古典伴随恒等式，$\boldsymbol{AC}=\boldsymbol{CA}=\boldsymbol{I}_n$，所以 $\boldsymbol{A}$ 可逆，且 $\boldsymbol{C}=\boldsymbol{A}^{-1}$。若 $\boldsymbol{BA}=\boldsymbol{I}_n$，则 $\boldsymbol{B}=\boldsymbol{B}(\boldsymbol{AC})=(\boldsymbol{BA})\boldsymbol{C}=\boldsymbol{C}$；若 $\boldsymbol{AB}=\boldsymbol{I}_n$，则 $\boldsymbol{B}=(\boldsymbol{CA})\boldsymbol{B}=\boldsymbol{C}(\boldsymbol{AB})=\boldsymbol{C}$。 ■

所以检验方阵的逆，只需验证一侧的乘积。矩形矩阵则不同：左逆与右逆可以只存在一个，也可以不唯一（示例 1.22）。

1.3.2 迹

行列式要用到方阵的全部元素。迹只看主对角线：n 阶方阵的**迹**（trace）是主对角元素之和，

$$\operatorname{tr}(\boldsymbol{A})=\sum_{i=1}^{n}A_{i,i}.$$

例如

$$\operatorname{tr}\begin{pmatrix}1&2\\3&4\end{pmatrix}=1+4=5,$$

而这个矩阵全部元素之和是 10。迹只对方阵定义，只累加对角元。

1.3.2.1 迹的性质

迹是有限和，前两条性质可以直接看出；第三条循环性是迹最常用的性质。

线性

$$\operatorname{tr}(a\boldsymbol{A}+b\boldsymbol{B})=a\operatorname{tr}(\boldsymbol{A})+b\operatorname{tr}(\boldsymbol{B}),$$

这是有限和的线性。

转置不变

$$\operatorname{tr}(\boldsymbol{A}^{\mathsf{T}})=\operatorname{tr}(\boldsymbol{A}),$$

因为转置不改变对角元。

循环性　对 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$、$\boldsymbol{B}\in\mathbb{R}^{n\times m}$，

$$\operatorname{tr}(\boldsymbol{AB})=\sum_{i=1}^{m}\sum_{j=1}^{n}A_{i,j}B_{j,i}=\operatorname{tr}(\boldsymbol{BA}). \tag{1.12}$$

两个双重和只是求和次序不同。$\boldsymbol{AB}$ 与 $\boldsymbol{BA}$ 可以是不同阶的方阵；相等的是它们的迹，不是矩阵本身。下面的例子说明这一点。

示例 1.33　不同阶乘积的迹相等　取行向量 $\boldsymbol{A}=\begin{bmatrix}1&2&3\end{bmatrix}\in\mathbb{R}^{1\times 3}$ 与列向量 $\boldsymbol{B}=(1,0,2)^{\mathsf{T}}\in\mathbb{R}^{3\times 1}$。按“行乘列”的次序，$\boldsymbol{AB}=1\cdot1+2\cdot0+3\cdot2=7$ 是 1×1 矩阵；按“列乘行”的次序，

$$\boldsymbol{BA}=\begin{bmatrix}1&2&3\\0&0&0\\2&4&6\end{bmatrix}$$

是 3×3 矩阵，对角元为 $1,0,6$。两个乘积连阶数都不同，迹却相等：$\operatorname{tr}(\boldsymbol{AB})=7=1+0+6=\operatorname{tr}(\boldsymbol{BA})$。$\boldsymbol{BA}$ 的对角元 $A_{1,j}B_{j,1}$ 恰好是内积 $\boldsymbol{AB}$ 中的三项。

三个因子时，循环性只允许把因子整体循环移动：

$$\operatorname{tr}(\boldsymbol{ABC})=\operatorname{tr}(\boldsymbol{BCA})=\operatorname{tr}(\boldsymbol{CAB}).$$

第一个等号把 $\boldsymbol{A}$ 与 $\boldsymbol{BC}$ 看作两个因子，使用式 (1.12)；第二个等号把 $\boldsymbol{AB}$ 与 $\boldsymbol{C}$ 看作两个因子。任意交换相邻因子则可能改变迹，下面是一个反例。

示例 1.34　反例：交换相邻因子会改变迹　取

$$\boldsymbol{A}=\begin{pmatrix}1&0\\0&0\end{pmatrix},\quad \boldsymbol{B}=\begin{pmatrix}0&0\\1&0\end{pmatrix},\quad \boldsymbol{C}=\begin{pmatrix}0&1\\0&0\end{pmatrix}.$$

其中 $\boldsymbol{A},\boldsymbol{B}$ 就是示例 1.11中的两个矩阵，$\boldsymbol{AB}=\boldsymbol{0}$，所以 $\boldsymbol{ABC}=\boldsymbol{0}$。把 $\boldsymbol{B}$ 与 $\boldsymbol{C}$ 对调：$\boldsymbol{C}$ 的非零元在第一行，$\boldsymbol{A}$ 保留第一行，故 $\boldsymbol{AC}=\boldsymbol{C}$，从而

$$\boldsymbol{ACB}=\begin{pmatrix}0&1\\0&0\end{pmatrix}\begin{pmatrix}0&0\\1&0\end{pmatrix}=\begin{pmatrix}1&0\\0&0\end{pmatrix}.$$

于是 $\operatorname{tr}(\boldsymbol{ABC})=0$，而 $\operatorname{tr}(\boldsymbol{ACB})=1$。$\boldsymbol{ACB}$ 不是 $\boldsymbol{ABC}$ 的循环移动，迹可以不同。

1.3.3 矩阵的元素内积

行列式和迹都只对方阵定义，只用到一个矩阵。比较两个同形矩阵时，可以像向量内积那样，把全部对应元素配对。

1.3.3.1 Frobenius 内积

把同形矩阵的 mn 个元素看作 mn 个坐标, 照搬欧氏内积, 就得到Frobenius内积：对 $\boldsymbol{A},\boldsymbol{B}\in\mathbb{R}^{m\times n}$,

$$\langle \boldsymbol{A},\boldsymbol{B}\rangle_{\mathrm{F}}=\sum_{i=1}^{m}\sum_{j=1}^{n}a_{i,j}b_{i,j}.$$

它把对应元素逐项相乘后全部相加，也就是 $\boldsymbol{A}\odot\boldsymbol{B}$ 全部元素之和。下面沿用逐项乘积一例中的两个矩阵。

示例 1.35　Frobenius 内积的计算　对

$$\boldsymbol{A}=\begin{pmatrix}1&2\\3&4\end{pmatrix},\quad \boldsymbol{B}=\begin{pmatrix}0&1\\1&0\end{pmatrix},$$

按位置 $(1,1),(1,2),(2,1),(2,2)$ 依次配对相乘再相加：

$$\langle \boldsymbol{A},\boldsymbol{B}\rangle_{\mathrm{F}}=1\cdot 0+2\cdot 1+3\cdot 1+4\cdot 0=5.$$

四个乘积正是示例 1.19中 $\boldsymbol{A}\odot\boldsymbol{B}$ 的四个元素 $0,2,3,0$，所以 Frobenius 内积就是逐项乘积的元素之和。

Frobenius 内积的迹表示　Frobenius 内积可以用迹写出：

$$\langle \boldsymbol{A},\boldsymbol{B}\rangle_{\mathrm{F}}=\operatorname{tr}(\boldsymbol{A}^{\top}\boldsymbol{B}),$$
$$\|\boldsymbol{A}\|_{\mathrm{F}}^{2}=\operatorname{tr}(\boldsymbol{A}^{\top}\boldsymbol{A}).$$

$\boldsymbol{A}^{\top}\boldsymbol{B}$ 的第 j 个对角元为 $\sum_i A_{i,j}B_{i,j}$，再对 j 求和，恰好遍历所有位置。第二式中的 $\|\boldsymbol{A}\|_{\mathrm{F}}$ 就是下面定义的 Frobenius 范数。反过来，计算 $\operatorname{tr}(\boldsymbol{AB})$ 时也不必先求出乘积：只需计算 $\sum_{i,j}A_{i,j}B_{j,i}$，代价为 mn 次乘法，而求出整个 $\boldsymbol{AB}$ 需要 m^2n 次。

1.3.3.2　Frobenius 范数

由 Frobenius 内积可以定义矩阵的大小。把矩阵当作一张数表，定义 Frobenius 范数

$$\|\boldsymbol{A}\|_{\mathrm{F}} = \sqrt{\langle \boldsymbol{A}, \boldsymbol{A} \rangle_{\mathrm{F}}} = \left(\sum_{i,j} a_{i,j}^2 \right)^{1/2}.$$

例如

$$\left\| \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \right\|_{\mathrm{F}} = \sqrt{1+4+9+16} = \sqrt{30}.$$

它就是把 mn 个元素排成一列以后的 2 范数，其范数性质在第 3.1.1节由 Minkowski 不等式统一验证。

Frobenius 范数也可以从矩阵的作用来理解。由 $\boldsymbol{A}\boldsymbol{e}_j = \boldsymbol{A}_{:,j}$，

$$\|\boldsymbol{A}\|_{\mathrm{F}}^2 = \sum_j \|\boldsymbol{A}_{:,j}\|_2^2 = \sum_j \|\boldsymbol{A}\boldsymbol{e}_j\|_2^2,$$

即全部标准坐标向量输入后，输出长度的平方和。它不是某一个最坏输入的放大倍数；后者是另一种矩阵范数，在第 3.3.4节讨论。

数据按组划分时，还可以先在组内汇总、再汇总各组，得到混合范数。例如以行为组，$\|\boldsymbol{A}\|_{p,q} = (\sum_i \|\boldsymbol{A}_{i,:}\|_p^q)^{1/q}$：内层的 p 范数衡量每一行的大小，外层的 q 范数汇总各行。

1.4　张量

一批图像要记录样本、通道和两个像素坐标，一批文本要记录样本、位置和特征维度。定位其中一个数需要三个甚至更多的索引，一张矩阵装不下。本节先给出多维数组的记法，再按对轴的作用讨论三类运算：重排只改变元素所在的位置；张量积与 Kronecker 积把几个数组组合成轴更多的数组；缩约沿指定的轴求和，把数组汇总成轴更少的数组。每类运算之后整理它的性质。最后会看到，前两节的内积、矩阵乘法与迹都是缩约。

1.4.1　张量的表示与重排

向量用一个索引定位一个数，矩阵用两个。一个量由更多路索引共同决定时，就需要更多索引。机器学习中常把这样的多索引数值数组称为**张量**（tensor）。

数学中的“张量”还有不依赖坐标的定义，例如多线性映射或张量积空间的元素；本节只采用坐标数组的口径，把张量当作一张多索引的数表。数组与多线性映射的联系，在第 2.3.5节选定基以后说明。

定义 1.36　多维数值数组　给定正整数 $n_1, \dots, n_k$，形状为 $n_1 \times \cdots \times n_k$ 的数值数组，是从 $\{1, \dots, n_1\} \times \cdots \times \{1, \dots, n_k\}$ 到 $\mathbb{R}$ 的映射。第 j 个索引称为第 j 个**轴**（axis），轴数 k 称为数组的**阶**（order）。

按这一定义，向量是一阶数组，矩阵是二阶数组；并约定单个标量是零阶数组。阶是索引的个数，形状记录各轴的长度。轴的长度再大也不改变阶：$\mathbb{R}^{100}$ 中的向量仍是一阶数组。

例如 $\boldsymbol{X} \in \mathbb{R}^{b \times \ell \times d}$ 可以记录 b 个样本、每个样本 ℓ 个位置、每个位置 d 个特征，元素 $x_{i,j,k}$ 由三个索引共同定位。固定一部分索引，得到切片：$\boldsymbol{X}_{i,:,:}$ 保留第 i 个样本，是一个 $\ell \times d$ 矩阵；$\boldsymbol{X}_{i,j,:}$ 再固定位置，是一个 d 维向量。图 1.3按“定位一个数需要几个索引”并排比较四类数组。

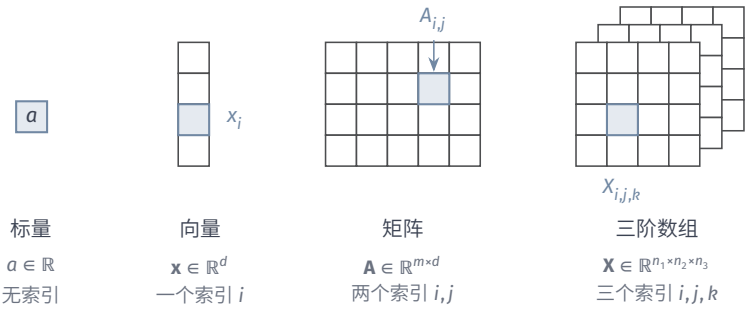


图 1.3　标量、向量、矩阵与三阶数组的区别。每个面板用蓝色标出一个数：标量本身就是这个数，向量用一个索引 i 定位，矩阵用行列两个索引 i, j 定位，三阶数组再加一个索引 k 选择切片。索引个数称为阶，各轴长度组成形状。

两个同形数组按位置逐项相加和数乘，规则与向量、矩阵相同。两个数组相加，仍要求形状相同、对应轴的含义相同。所以使用多维数组时，要先说清每条轴记录什么。同一个 $b \times \ell \times d$ 数组，若把第二、三轴的含义弄反，后面的每一次汇总都会汇总到错误的轴上。

先看第一类运算：重排。轴置换与形状重整只改变元素记录在哪条轴、哪个位置上，既不改变数值，也不求和。

1.4.1.1 轴置换

维度重排（permutation of axes）也称轴置换，它按给定顺序调换轴的位置，每个元素跟着自己的索引移动。计算时先写出新旧索引的对应，再按对应搬运元素。例如把 $\boldsymbol{X} \in \mathbb{R}^{b \times \ell \times d}$ 的第二、三轴互换，得到 $\boldsymbol{Y} \in \mathbb{R}^{b \times d \times \ell}$，

$$y_{i,k,j} = x_{i,j,k}.$$

第一轴保持原位，每个样本的切片被转置：$\boldsymbol{Y}_{i,:,:} = (\boldsymbol{X}_{i,:,:})^{\top}$。下面取一个具体的小数组。

示例 1.37　交换后两条轴　取 $b = 1$、$\ell = 2$、$d = 3$，这时数组只有一个样本切片

$$\boldsymbol{X}_{1,:,:} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}.$$

按 $y_{1,k,j} = x_{1,j,k}$ 逐个搬运元素。例如原来位于第 2 个位置、第 3 个特征的 6，搬到 $y_{1,3,2}$。全部搬完，得到

$$\boldsymbol{Y}_{1,:,:} = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix}.$$

新数组 $\boldsymbol{Y} \in \mathbb{R}^{1\times 3\times 2}$ 的样本切片正是原切片的转置，数值一个也没有改变。

只有两条轴时，唯一不平凡的轴置换就是矩阵的转置。轴的含义跟着轴走，不因位置改变而改变：$\boldsymbol{Y}$ 的第二轴仍是特征，第三轴仍是位置。

1.4.1.2　形状重整与向量化

形状重整（reshape）分两步：先按指定的遍历顺序把全部元素读成一个数列，再把这个数列按同样的顺序装入另一种形状。它只要求元素总数不变。形状重整与转置都能把 2×3 矩阵变成 3×2 矩阵，但结果不同。

示例 1.38　按行重整与转置的区别　把

$$\boldsymbol{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$$

按行重整为 3×2 数组：先按行读出数列 $1, 2, 3, 4, 5, 6$，再按行依次装入，得到下面的 $\boldsymbol{R}$。作为对照，同时写出转置 $\boldsymbol{A}^{\top}$：

$$\boldsymbol{R} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix},$$

$$\text{而} \qquad \boldsymbol{A}^{\top} = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix}.$$

> $\boldsymbol{R}$ 与 $\boldsymbol{A}^{\top}$ 形状相同、所含的数相同，排列却不同。$\boldsymbol{A}^{\top}$ 的第一列是 $\boldsymbol{A}$ 原来的第一行 $1,2,3$，$\boldsymbol{R}$ 的第一列却是 $1,3,5$，把原来的行拆散了。

所以描述一次重整，除了目标形状，还要给出遍历顺序；形状对了，也不说明完成了轴交换。图 1.4把两种结果并排放置。

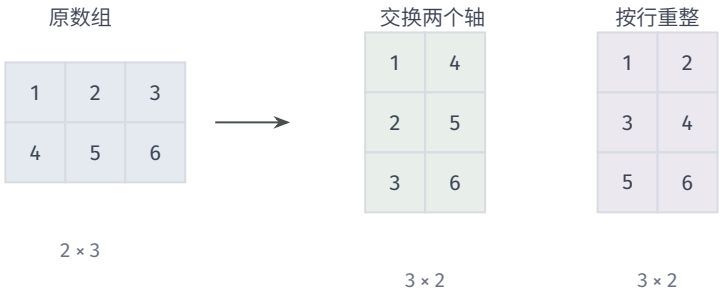


图 1.4　轴交换与按行重整。原数组两行为 $(1,2,3)$ 与 $(4,5,6)$；中图转置后两列分别保留原来的两行，右图则把按行读取的数列 $1,2,3,4,5,6$ 依次装入 3×2 数组。数字及其排列与正文示例相同。

最常用的一种形状重整，是把矩阵按列堆叠成一个长列向量，称为**向量化**（vectorization）：

$$\operatorname{vec}(\boldsymbol{A}) = (a_{1,1},\dots,a_{m,1},a_{1,2},\dots,a_{m,2},\dots,a_{1,n},\dots,a_{m,n})^{\top}.$$

$m\times n$ 矩阵的元素 $a_{i,j}$ 位于第 $i+(j-1)m$ 个位置。例如上面的 $\boldsymbol{A}$ 给出 $\operatorname{vec}(\boldsymbol{A}) = (1,4,2,5,3,6)^{\top}$，其中 $a_{2,3}=6$ 位于第 $2+(3-1)\cdot 2 = 6$ 个位置。

多维数组也可以重整成矩阵，称为矩阵展开（unfolding）：把一部分轴合并成行索引，其余轴合并成列索引。例如把 $\boldsymbol{X}\in\mathbb{R}^{b\times \ell\times d}$ 的前两轴合并为行，得到 $b\ell\times d$ 矩阵，每行是一个样本在一个位置上的特征。合并哪些轴，决定了展开结果的形状，也决定了后续乘积汇总哪条轴。

1.4.1.3 重排的性质

固定轴的顺序和遍历规则以后，重排有三条性质：它不丢失信息，与逐项运算可交换，但一般的形状重整与矩阵乘法不相容。

可逆性　目标形状与遍历顺序固定后，轴置换、形状重整与向量化都把一个数组一一对应到另一个数组，逆操作可以恢复原数组：

$$(\boldsymbol{A}^{\top})^{\top} = \boldsymbol{A},\qquad \operatorname{vec}^{-1}\bigl(\operatorname{vec}(\boldsymbol{A})\bigr) = \boldsymbol{A}.$$

这里 vec^{-1} 把长度为 mn 的向量依次每 m 个一列装回 $m\times n$ 矩阵。一般的轴置换按逆置换换回，形状重整按原顺序装回。所以重排保留全部信息。

线性

$$\mathrm{vec}(a\boldsymbol{A}+b\boldsymbol{B})=a\,\mathrm{vec}(\boldsymbol{A})+b\,\mathrm{vec}(\boldsymbol{B}).$$

轴置换与形状重整同样满足这一性质：它们只搬动元素，逐项的加法与数乘搬到新位置后不变。

与矩阵乘法的关系　转置与乘法有整齐的规则

$$(\boldsymbol{AB})^{\top}=\boldsymbol{B}^{\top}\boldsymbol{A}^{\top},$$

一般的形状重整却没有。重整以后，每一行、每一列汇集的元素都变了，依赖行列结构的乘积、迹与行列式一般随之改变。下面的反例把示例 1.38中的 $\boldsymbol{R}$ 误当作 $\boldsymbol{A}^{\top}$ 使用。

示例 1.39　反例：重整不能代替转置　仍取 $\boldsymbol{A}$ 与按行重整得到的 $\boldsymbol{R}$，

$$\boldsymbol{A}=\begin{bmatrix}1&2&3\\4&5&6\end{bmatrix},\qquad \boldsymbol{R}=\begin{bmatrix}1&2\\3&4\\5&6\end{bmatrix}.$$

示例 1.15已经算出

$$\boldsymbol{A}\boldsymbol{A}^{\top}=\begin{bmatrix}14&32\\32&77\end{bmatrix};$$

而

$$\boldsymbol{A}\boldsymbol{R}=\begin{bmatrix}1+6+15&2+8+18\\4+15+30&8+20+36\end{bmatrix}=\begin{bmatrix}22&28\\49&64\end{bmatrix}.$$

$\boldsymbol{R}$ 与 $\boldsymbol{A}^{\top}$ 形状相同、所含的数相同，两个乘积却完全不同：$\boldsymbol{AR}$ 不对称，迹也从 $14+77=91$ 变成 $22+64=86$。原因是乘积按行列配对元素，而重整改变了哪些元素同在一列。

把存储格式的改变误当成计算上的变换，是使用重整时最常见的错误。

1.4.2　张量积

第二类运算把几个数组组合起来。最基本的情形是两个向量：把它们的全部两两乘积排成一个数组，就是张量积。

设 $\boldsymbol{x}\in\mathbb{R}^{m}$、$\boldsymbol{y}\in\mathbb{R}^{n}$，**张量积**（tensor product）$\boldsymbol{x}\otimes\boldsymbol{y}$ 是 $m\times n$ 数组，

$$(\boldsymbol{x}\otimes\boldsymbol{y})_{i,j}=x_i y_j.$$

写成矩阵，$\boldsymbol{x}\otimes\boldsymbol{y}=\boldsymbol{x}\boldsymbol{y}^{\mathsf{T}}$，正是分块乘法式 (1.7)中“一列乘一行”的矩阵。每个因子各占结果的一条轴，下面把这条轴称为该因子的槽位。三个向量的张量积 $(\boldsymbol{x}\otimes\boldsymbol{y}\otimes\boldsymbol{z})_{i,j,k}=x_iy_jz_k$ 有三个槽位，更多因子按同样规则逐槽位相乘。下面计算两个二维向量的张量积。

示例 1.40　两个二维向量的张量积　取 $\boldsymbol{x}=(1,2)^{\mathsf{T}}$ 与 $\boldsymbol{y}=(3,-1)^{\mathsf{T}}$，把 x_i 与 y_j 的乘积填在位置 (i,j)：

$$\boldsymbol{x}\otimes\boldsymbol{y}=\begin{pmatrix}1\cdot3 & 1\cdot(-1)\\ 2\cdot3 & 2\cdot(-1)\end{pmatrix}=\begin{pmatrix}3 & -1\\ 6 & -2\end{pmatrix}.$$

第二行 $(6,-2)$ 恰是第一行 $(3,-1)$ 的 2 倍。一般地，第 i 行是 $x_i\boldsymbol{y}^{\mathsf{T}}$，每一行都是 $\boldsymbol{y}^{\mathsf{T}}$ 的倍数；同理，每一列都是 $\boldsymbol{x}$ 的倍数。

两个因子的长度不必相同。图 1.5取 $\boldsymbol{u}=(1,2)^{\mathsf{T}}$ 与三维的 $\boldsymbol{v}=(3,-1,2)^{\mathsf{T}}$：第一个因子占行轴，第二个因子占列轴，结果的第 i 行是 $u_i\boldsymbol{v}^{\mathsf{T}}$，第 j 列是 $v_j\boldsymbol{u}$。

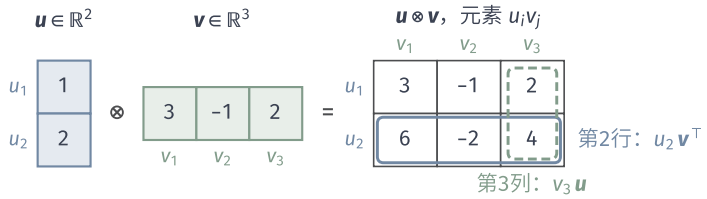


图 1.5　张量积的两个槽位。左：$\boldsymbol{u}=(1,2)^{\mathsf{T}}\in\mathbb{R}^2$ 竖排，$\boldsymbol{v}=(3,-1,2)^{\mathsf{T}}\in\mathbb{R}^3$ 横排。右：$\boldsymbol{u}\otimes\boldsymbol{v}$ 是 2×3 数组，行由 u_i 标记、列由 v_j 标记，位置 (i,j) 的元素为 u_iv_j。蓝色实线框标出第 2 行 $(6,-2,4)=u_2\boldsymbol{v}^{\mathsf{T}}$，绿色虚线框标出第 3 列 $(2,4)^{\mathsf{T}}=v_3\boldsymbol{u}$。数值由定义直接相乘得到，是教学构造。

同样的配对规则适用于任意有限数组。设 $\boldsymbol{A}$ 有 k 条轴、形状为 $n_1\times\cdots\times n_k$，$\boldsymbol{B}$ 有 ℓ 条轴、形状为 $m_1\times\cdots\times m_\ell$。它们的数组张量积保留两组索引：

$$(\boldsymbol{A}\otimes\boldsymbol{B})_{i_1,\dots,i_k,j_1,\dots,j_\ell}=a_{i_1,\dots,i_k}b_{j_1,\dots,j_\ell}.$$

输出有 $k+\ell$ 条轴，长度依次与输入的各轴相同；这里没有对任何索引求和。交换两个输入，会同时交换两组轴的次序。实数乘积 $ab=ba$，并不意味着 $\boldsymbol{A}\otimes\boldsymbol{B}$ 与 $\boldsymbol{B}\otimes\boldsymbol{A}$ 相同。

形如 $\boldsymbol{x}\otimes\boldsymbol{y}$ 的数组称为**简单张量**（simple tensor）。由示例 1.40，简单张量的各行都是同一个向量的倍数。所以并非每个二阶数组都是简单张量，下面是一个反例。

示例 1.41　反例：单位矩阵不是简单张量　$\boldsymbol{I}_2$ 的两行为 $(1,0)$ 与 $(0,1)$。假设 $\boldsymbol{I}_2 = \boldsymbol{x} \otimes \boldsymbol{y}$，则两行分别是 $x_1\boldsymbol{y}^{\top}$ 与 $x_2\boldsymbol{y}^{\top}$。两行都非零，所以 $x_1, x_2 \neq 0$，两行都是 $\boldsymbol{y}^{\top}$ 的非零倍数，从而彼此成比例。但 $(1,0)$ 与 $(0,1)$ 不成比例，矛盾。所以 $\boldsymbol{I}_2$ 不能写成任何 $\boldsymbol{x} \otimes \boldsymbol{y}$，它不是简单张量。

不过，每个 $m \times n$ 数组 $\boldsymbol{T}$ 都是简单张量的和：

$$\boldsymbol{T} = \sum_{i,j} t_{i,j}\, \boldsymbol{e}_i \otimes \boldsymbol{f}_j,$$

其中 $\boldsymbol{e}_i$、$\boldsymbol{f}_j$ 分别是 $\mathbb{R}^m$ 与 $\mathbb{R}^n$ 的标准坐标向量，$\boldsymbol{e}_i \otimes \boldsymbol{f}_j$ 只在位置 (i,j) 为 1。

张量积的用处，是把同时依赖两组输入的计算，化为对单个数组的线性计算。设实值函数 $B(\boldsymbol{x}, \boldsymbol{y})$ 对 $\boldsymbol{x}$、$\boldsymbol{y}$ 分别保持线性组合，这样的函数称为双线性的。把 $\boldsymbol{x} = \sum_i x_i \boldsymbol{e}_i$、$\boldsymbol{y} = \sum_j y_j \boldsymbol{f}_j$ 代入，按两次线性展开，

$$B(\boldsymbol{x}, \boldsymbol{y}) = \sum_{i,j} x_i y_j\, B(\boldsymbol{e}_i, \boldsymbol{f}_j) = \sum_{i,j} g_{i,j} (\boldsymbol{x} \otimes \boldsymbol{y})_{i,j} = \langle \boldsymbol{G}, \boldsymbol{x} \otimes \boldsymbol{y} \rangle_{\mathrm{F}},$$

其中 $g_{i,j} = B(\boldsymbol{e}_i, \boldsymbol{f}_j)$。所以双线性函数由一张固定的系数表 $\boldsymbol{G}$ 决定，并且它作为 $\boldsymbol{x} \otimes \boldsymbol{y}$ 的函数是线性的。以欧氏内积 $B(\boldsymbol{x}, \boldsymbol{y}) = \boldsymbol{x}^{\top}\boldsymbol{y}$（$m = n$）为例，$g_{i,j} = \langle \boldsymbol{e}_i, \boldsymbol{e}_j \rangle$，即 $\boldsymbol{G} = \boldsymbol{I}$，这时计算就是把 $\boldsymbol{x} \otimes \boldsymbol{y}$ 的对角元加起来。

二阶张量与矩阵是同一组数的两种看法：张量强调每个槽位来自哪一组输入，矩阵强调行与列在乘法中的角色。

1.4.2.1　张量积的性质

张量积的每个元素都是各因子元素的乘积，下面的性质都从这个元素公式逐槽位验证。

对每个因子线性

$$\begin{aligned}
(a\boldsymbol{x}) \otimes \boldsymbol{y} &= \boldsymbol{x} \otimes (a\boldsymbol{y}) = a(\boldsymbol{x} \otimes \boldsymbol{y}), \\
(\boldsymbol{x} + \boldsymbol{x}') \otimes \boldsymbol{y} &= \boldsymbol{x} \otimes \boldsymbol{y} + \boldsymbol{x}' \otimes \boldsymbol{y}, \\
\boldsymbol{x} \otimes (\boldsymbol{y} + \boldsymbol{y}') &= \boldsymbol{x} \otimes \boldsymbol{y} + \boldsymbol{x} \otimes \boldsymbol{y}'.
\end{aligned}$$

每个元素 $x_i y_j$ 对 x_i 和 y_j 分别线性，逐项验证即得。

结合律

$$(\boldsymbol{x} \otimes \boldsymbol{y}) \otimes \boldsymbol{z} = \boldsymbol{x} \otimes (\boldsymbol{y} \otimes \boldsymbol{z}),$$

两边的 (i,j,k) 元素都是 $x_i y_j z_k$。

交换槽位是转置

$$\boldsymbol{y}\otimes\boldsymbol{x} = (\boldsymbol{x}\otimes\boldsymbol{y})^{\mathsf{T}},$$

因为 $\boldsymbol{x}\otimes\boldsymbol{y}$ 的 (i,j) 元素 $x_i y_j$ 也是 $\boldsymbol{y}\otimes\boldsymbol{x}$ 的 (j,i) 元素。所以一般 $\boldsymbol{x}\otimes\boldsymbol{y}\neq\boldsymbol{y}\otimes\boldsymbol{x}$，两者相差一次轴置换。

Frobenius 配对与范数分离

$$\langle \boldsymbol{x}\otimes\boldsymbol{y}, \boldsymbol{x}'\otimes\boldsymbol{y}'\rangle_{\mathrm{F}} = \langle\boldsymbol{x},\boldsymbol{x}'\rangle\langle\boldsymbol{y},\boldsymbol{y}'\rangle,$$
$$\|\boldsymbol{x}\otimes\boldsymbol{y}\|_{\mathrm{F}} = \|\boldsymbol{x}\|_2\,\|\boldsymbol{y}\|_2.$$

第一式来自 $\sum_{i,j} x_i y_j x'_i y'_j = (\sum_i x_i x'_i)(\sum_j y_j y'_j)$；在第一式中取 $\boldsymbol{x}'=\boldsymbol{x}$、$\boldsymbol{y}'=\boldsymbol{y}$，再开平方，得到第二式。下面在示例 1.40的数组上核对第二式。

示例 1.42　张量积范数的数值核对　仍取 $\boldsymbol{x}=(1,2)^{\mathsf{T}}$ 与 $\boldsymbol{y}=(3,-1)^{\mathsf{T}}$，它们的张量积为

$$\boldsymbol{x}\otimes\boldsymbol{y} = \begin{pmatrix} 3 & -1 \\ 6 & -2 \end{pmatrix}.$$

按公式右端，只需两个向量各自的长度：$\|\boldsymbol{x}\|_2=\sqrt{5}$，$\|\boldsymbol{y}\|_2=\sqrt{10}$，乘积为 $\sqrt{5}\cdot\sqrt{10}=\sqrt{50}=5\sqrt{2}$。直接对四个元素求 Frobenius 范数，

$$\|\boldsymbol{x}\otimes\boldsymbol{y}\|_{\mathrm{F}} = \sqrt{3^2+(-1)^2+6^2+(-2)^2} = \sqrt{50},$$

两种算法一致。

与行列式的联系　把张量积反对称化，得到 $\boldsymbol{x}\otimes\boldsymbol{y}-\boldsymbol{y}\otimes\boldsymbol{x}$。它的 (i,j) 元素为

$$x_i y_j - x_j y_i = \det\begin{pmatrix} x_i & y_i \\ x_j & y_j \end{pmatrix},$$

即把 $\boldsymbol{x},\boldsymbol{y}$ 投影到第 i,j 两个坐标构成的平面后张成的有向面积（第 1.3.1节）。交换 $\boldsymbol{x},\boldsymbol{y}$ 时，每个元素都变号。

1.4.3　Kronecker 积

两个矩阵分别作用在两条轴上时，可以把联合作用写成一张大矩阵，这就是 Kronecker 积。对 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$、$\boldsymbol{B}\in\mathbb{R}^{p\times q}$，定义

$$\boldsymbol{A}\otimes\boldsymbol{B}=\begin{bmatrix}A_{1,1}\boldsymbol{B} & \cdots & A_{1,n}\boldsymbol{B}\\ \vdots & \ddots & \vdots\\ A_{m,1}\boldsymbol{B} & \cdots & A_{m,n}\boldsymbol{B}\end{bmatrix}\in\mathbb{R}^{mp\times nq}. \tag{1.13}$$

计算时，把 $\boldsymbol{A}$ 的每个元素 $A_{i,j}$ 替换成块 $A_{i,j}\boldsymbol{B}$。下面计算一个二阶的例子。

示例 1.43　两个二阶矩阵的 Kronecker 积　取

$$\boldsymbol{A}=\begin{bmatrix}1&2\\3&4\end{bmatrix},\quad \boldsymbol{B}=\begin{bmatrix}0&1\\1&0\end{bmatrix},$$

把 $\boldsymbol{A}$ 的四个元素分别换成块 $1\cdot\boldsymbol{B}$、$2\cdot\boldsymbol{B}$、$3\cdot\boldsymbol{B}$、$4\cdot\boldsymbol{B}$：

$$\boldsymbol{A}\otimes\boldsymbol{B}=\begin{bmatrix}1\cdot\boldsymbol{B}&2\cdot\boldsymbol{B}\\3\cdot\boldsymbol{B}&4\cdot\boldsymbol{B}\end{bmatrix}=\begin{bmatrix}0&1&0&2\\1&0&2&0\\0&3&0&4\\3&0&4&0\end{bmatrix}.$$

结果是 4×4 矩阵。每个 2×2 块都是 $\boldsymbol{B}$ 乘以 $\boldsymbol{A}$ 的一个元素，块的排列照搬 $\boldsymbol{A}$ 中元素的位置：$\boldsymbol{A}$ 的形状与元素决定块怎样排、各乘多少，$\boldsymbol{B}$ 决定每块内部的样子。

图 1.6用另一组数展示这种逐元素替换得到的分块结构。

Kronecker 积与张量积用同一个记号 $\otimes$，两者记录的是同一组数，只是排法不同。两个列向量按式 (1.13)相乘，得到 mn 维长向量 $(x_1\boldsymbol{y}^{\mathsf{T}},\dots,x_m\boldsymbol{y}^{\mathsf{T}})^{\mathsf{T}}$，它正是把 $m\times n$ 数组 $\boldsymbol{x}\otimes\boldsymbol{y}$ 按行读出的结果。例如 $(1,2)^{\mathsf{T}}\otimes(3,-1)^{\mathsf{T}}=(3,-1,6,-2)^{\mathsf{T}}$，与示例 1.40中的数组按行读出的结果相同。对一般矩阵，数组张量积保留四条轴，Kronecker 积把它们排成两条轴。遇到记号 $\otimes$ 时，须根据上下文和输出形状判断是哪一种。

1.4.3.1　Kronecker 积的性质

Kronecker 积是分块矩阵，下面的乘法、转置、逆和迹的规则都可以用块运算验证。最后一条向量化恒等式在求解矩阵方程时要用到。

分别作用于两个槽位

$$(\boldsymbol{A}\otimes\boldsymbol{B})(\boldsymbol{x}\otimes\boldsymbol{y})=(\boldsymbol{A}\boldsymbol{x})\otimes(\boldsymbol{B}\boldsymbol{y}).$$

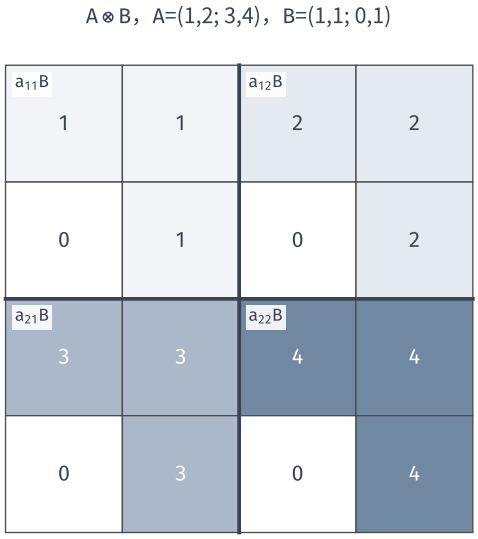


图 1.6 Kronecker 积的分块结构。上：$\boldsymbol{A}=\left(\begin{smallmatrix}1&2\\3&4\end{smallmatrix}\right)$、$\boldsymbol{B}=\left(\begin{smallmatrix}10&20\\30&40\end{smallmatrix}\right)$。下：$\boldsymbol{A}\otimes\boldsymbol{B}$ 是把 $\boldsymbol{A}$ 的每个元素替换为该元素乘 $\boldsymbol{B}$ 得到的 4×4 分块矩阵，块边界用白线强调。数值由定义直接计算，是教学例。

按分块乘法，左侧第 i 块为 $\sum_j A_{i,j}\boldsymbol{B}(x_j\boldsymbol{y})=(\sum_j A_{i,j}x_j)\boldsymbol{B}\boldsymbol{y}=(\boldsymbol{A}\boldsymbol{x})_i\,\boldsymbol{B}\boldsymbol{y}$，正是右侧的第 i 块。第一个槽位只经过 $\boldsymbol{A}$，第二个槽位只经过 $\boldsymbol{B}$，两个作用并排进行。矩阵乘法则不同，它把前后两次作用串成一条链。

混合乘积 当 $\boldsymbol{AC}$ 与 $\boldsymbol{BD}$ 都有定义时，

$$(\boldsymbol{A}\otimes\boldsymbol{B})(\boldsymbol{C}\otimes\boldsymbol{D})=(\boldsymbol{AC})\otimes(\boldsymbol{BD}). \tag{1.14}$$

按分块乘法，左侧的块 (i,k) 为 $\sum_j(A_{i,j}\boldsymbol{B})(C_{j,k}\boldsymbol{D})=(\sum_j A_{i,j}C_{j,k})\boldsymbol{BD}=(\boldsymbol{AC})_{i,k}\boldsymbol{BD}$，恰是右侧的块。上一条是 $\boldsymbol{C},\boldsymbol{D}$ 各只有一列的特例。

转置

$$(\boldsymbol{A}\otimes\boldsymbol{B})^{\top}=\boldsymbol{A}^{\top}\otimes\boldsymbol{B}^{\top}.$$

分块矩阵转置时，块的位置交换，每块各自转置，所以第 (j,i) 块为 $A_{i,j}\boldsymbol{B}^{\top}$，正是 $\boldsymbol{A}^{\top}\otimes\boldsymbol{B}^{\top}$ 的第 (j,i) 块。

逆

$$(\boldsymbol{A}\otimes\boldsymbol{B})^{-1}=\boldsymbol{A}^{-1}\otimes\boldsymbol{B}^{-1}\qquad(\boldsymbol{A},\boldsymbol{B}\text{都可逆}).$$

由混合乘积，$(\boldsymbol{A}\otimes\boldsymbol{B})(\boldsymbol{A}^{-1}\otimes\boldsymbol{B}^{-1})=(\boldsymbol{A}\boldsymbol{A}^{-1})\otimes(\boldsymbol{B}\boldsymbol{B}^{-1})=\boldsymbol{I}\otimes\boldsymbol{I}=\boldsymbol{I}$，另一侧同理。

迹

$$\operatorname{tr}(\boldsymbol{A}\otimes\boldsymbol{B})=\operatorname{tr}\boldsymbol{A}\,\operatorname{tr}\boldsymbol{B}\qquad(\boldsymbol{A},\boldsymbol{B}\text{都是方阵}).$$

只有对角块 $A_{i,i}\boldsymbol{B}$ 的对角元落在主对角线上，所以迹为 $\sum_i A_{i,i}\operatorname{tr}\boldsymbol{B}=\operatorname{tr}\boldsymbol{A}\,\operatorname{tr}\boldsymbol{B}$。

向量化恒等式　对 $\boldsymbol{A}\in\mathbb{R}^{p\times m}$、$\boldsymbol{X}\in\mathbb{R}^{m\times n}$、$\boldsymbol{B}\in\mathbb{R}^{n\times q}$，

$$\operatorname{vec}(\boldsymbol{A}\boldsymbol{X}\boldsymbol{B})=(\boldsymbol{B}^{\top}\otimes\boldsymbol{A})\operatorname{vec}(\boldsymbol{X}).\tag{1.15}$$

比较两侧输出的第 j 段（长度为 p）。左侧是 $\boldsymbol{A}\boldsymbol{X}\boldsymbol{B}$ 的第 j 列，$\boldsymbol{A}\boldsymbol{X}\boldsymbol{B}_{:,j}=\sum_k B_{k,j}\boldsymbol{A}\boldsymbol{X}_{:,k}$。右侧矩阵的第 j 个块行为 $(B_{1,j}\boldsymbol{A},\dots,B_{n,j}\boldsymbol{A})$，与 $\operatorname{vec}(\boldsymbol{X})$ 的各段 $\boldsymbol{X}_{:,1},\dots,\boldsymbol{X}_{:,n}$ 相乘，也得到 $\sum_k B_{k,j}\boldsymbol{A}\boldsymbol{X}_{:,k}$。逐元素写出，两侧 (i,j) 位置的元素都是 $\sum_{\ell=1}^{m}\sum_{k=1}^{n}A_{i,\ell}X_{\ell,k}B_{k,j}$。

固定 $\boldsymbol{A},\boldsymbol{B}$ 后，这个恒等式把“两侧同时乘矩阵”写成长向量 $\operatorname{vec}(\boldsymbol{X})$ 左乘一张矩阵。关于未知矩阵的方程由此化成普通的线性方程组；第 16章求解矩阵方程时会用到它。

1.4.4 指标缩约

张量积保留全部槽位；第三类运算缩约则相反，它沿指定的轴求和，减少轴的个数。

计算时选定一对或几对长度相同的轴，让每对轴共用同一个求和索引，逐项相乘后对这些索引求和。被求和的轴消失，其余的轴按原次序保留，组成输出的形状。写出索引，就能检查哪些轴被消去、哪些轴被保留。下面用两个例子说明。

示例 1.44　两种缩约的输出形状　(1) 设 $\boldsymbol{A}\in\mathbb{R}^{m\times d\times r}$，$\boldsymbol{B}\in\mathbb{R}^{d\times n\times r}$。让 $\boldsymbol{A}$ 的第二轴与 $\boldsymbol{B}$ 的第一轴共用索引 k，两者的第三轴共用索引 s：

$$c_{i,j}=\sum_{k=1}^{d}\sum_{s=1}^{r}a_{i,k,s}b_{k,j,s}.$$

两对轴同时被消去，只剩 $\boldsymbol{A}$ 的第一轴 i 和 $\boldsymbol{B}$ 的第二轴 j，所以输出是 $m\times n$ 矩阵。

（2）设 $\boldsymbol{X} \in \mathbb{R}^{b\times \ell \times d}$ 记录一批样本在各位置上的特征，$\boldsymbol{W} \in \mathbb{R}^{d\times h}$。让 $\boldsymbol{X}$ 的最后一轴与 $\boldsymbol{W}$ 的第一轴共用索引 k：

$$z_{i,j,t} = \sum_{k=1}^{d} x_{i,j,k} w_{k,t}.$$

这次只消去 k，保留 i, j, t，输出形状为 $b \times \ell \times h$。与（1）相比，这里只配对一对轴，样本轴和位置轴都原样保留：每个样本、每个位置上的 d 维特征都乘了同一个矩阵 $\boldsymbol{W}$。

图 1.7画出沿一对轴求和、保留其余轴的过程。

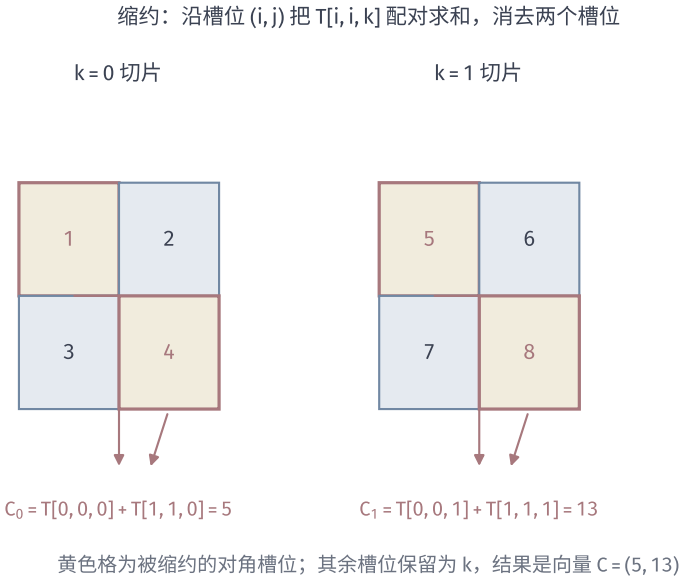


图 1.7　张量缩约沿选中的一对轴求和、保留其余轴。左：二阶张量按行和列着色；选中列轴（虚线箭头）沿列求和，输出对每行汇总为一个值。右：缩约后得到 3 个输出，分别对应原矩阵三行的行和，颜色由红（小）经黄到蓝（大）。张量与数值均为解析教学例。

图中对每行求和，也可以看成与全 1 向量沿列轴缩约。前两节的几种运算都是缩约：

- 内积 $\sum_j x_j y_j$ 缩约两个向量唯一的一对轴，输出标量；
- 矩阵乘法 $\sum_\ell a_{i,\ell} b_{\ell,j}$ 只消去左因子的列轴与右因子的行轴这一对；
- 迹 $\sum_i A_{i,i}$ 让同一个矩阵的行轴与列轴共用一个索引，再求和；
- Frobenius 内积 $\sum_{i,j} a_{i,j} b_{i,j}$ 同时缩约两对轴。

1.4.4.1 缩约的性质

缩约只由有限次乘法与求和组成，因此满足以下规则。

线性　固定参与配对的另一个数组，缩约对被作用的数组是线性的。以示例 1.44（2）中与 $\boldsymbol{W}$ 的缩约为例，把 $\boldsymbol{X}$ 换成 $a\boldsymbol{X}+b\boldsymbol{X}'$，

$$\sum_{k=1}^{d}(a\,x_{i,j,k}+b\,x'_{i,j,k})w_{k,t}=a\sum_{k=1}^{d}x_{i,j,k}w_{k,t}+b\sum_{k=1}^{d}x'_{i,j,k}w_{k,t},$$

输出变为两个输出的 a 倍与 b 倍之和。一般情形同理：每个输出元素都是被作用数组元素以固定系数作的加权和。

求和次序可交换　多对轴的缩约是有限和，结果与先消去哪一对轴无关。例如示例 1.44中的 $c_{i,j}$，可以先对 s 求和得到中间数组，再对 k 求和，也可以反过来：

$$c_{i,j}=\sum_{k=1}^{d}\Big(\sum_{s=1}^{r}a_{i,k,s}b_{k,j,s}\Big)=\sum_{s=1}^{r}\Big(\sum_{k=1}^{d}a_{i,k,s}b_{k,j,s}\Big).$$

简单张量系数可分离　设一次计算同时依赖三组向量 $\boldsymbol{x}\in\mathbb{R}^m$、$\boldsymbol{y}\in\mathbb{R}^n$、$\boldsymbol{z}\in\mathbb{R}^p$。若系数数组是简单张量 $\boldsymbol{a}\otimes\boldsymbol{b}\otimes\boldsymbol{c}$，则

$$\langle\boldsymbol{a}\otimes\boldsymbol{b}\otimes\boldsymbol{c},\boldsymbol{x}\otimes\boldsymbol{y}\otimes\boldsymbol{z}\rangle_{\mathrm{F}}=(\boldsymbol{a}^{\top}\boldsymbol{x})(\boldsymbol{b}^{\top}\boldsymbol{y})(\boldsymbol{c}^{\top}\boldsymbol{z}).\tag{1.16}$$

这是因为 $\sum_{i,j,k}a_ib_jc_kx_iy_jz_k=(\sum_i a_ix_i)(\sum_j b_jy_j)(\sum_k c_kz_k)$：三重求和分离成三个内积的乘积，计算量从 mnp 项降到 $m+n+p$ 项。下面用一组小数值核对。

示例 1.45　简单张量系数的分离计算　取 $m=n=p=2$，系数向量为 $\boldsymbol{a}=(1,2)^{\top}$、$\boldsymbol{b}=(3,-1)^{\top}$、$\boldsymbol{c}=(2,1)^{\top}$，输入为 $\boldsymbol{x}=(2,1)^{\top}$、$\boldsymbol{y}=(1,1)^{\top}$、$\boldsymbol{z}=(1,-1)^{\top}$。按式 (1.16)右端，只需三个内积：

$$\boldsymbol{a}^{\top}\boldsymbol{x}=1\cdot2+2\cdot1=4,\qquad\boldsymbol{b}^{\top}\boldsymbol{y}=3\cdot1+(-1)\cdot1=2,$$
$$\boldsymbol{c}^{\top}\boldsymbol{z}=2\cdot1+1\cdot(-1)=1.$$

三个内积相乘得 $4\cdot2\cdot1=8$。若直接展开三重求和，要累加 $2^3=8$ 项、每项是六个数的乘积，结果同样是 8。分离计算只需对 $m+n+p=6$ 个坐标各做一次乘法，维数增大时，它比逐项展开省下的计算迅速增多。

非线性操作不是缩约 由上面的线性，固定配对数组的缩约 $\mathcal{C}$ 满足 $\mathcal{C}(2\boldsymbol{X}) = 2\,\mathcal{C}(\boldsymbol{X})$。逐元素平方这样的逐元素非线性操作不满足这一点：只要 $x_{i,j} \neq 0$，

$$(2x_{i,j})^2 = 4x_{i,j}^2 \neq 2x_{i,j}^2,$$

所以它不是缩约；softmax 等操作同样不是缩约。一个模型若由缩约与这些操作交替组成，那么即使固定了系数、每一步缩约都是线性的，也不能由此推出整个模型是线性的。

1.5 本章小结

本章按定位一个数所需的索引个数，依次讨论了向量、矩阵与张量的运算。对每种运算，我们都交代了输入条件、输出形状和可用的规则。

向量的加法与数乘逐坐标进行，组合起来就是线性组合。欧氏内积把两个同维向量配成一个数，长度和 p 范数用一个非负数衡量向量的大小。它们的一般性质在第 3章统一建立。

矩阵乘法来自两次加权求和的复合。它满足结合律与分配律，但不满足交换律与消去律。初等行变换都可以撤销，用它把矩阵化成阶梯形，就能读出主元和自由变量；把方阵与单位矩阵并排作行变换，就能求出逆矩阵。逆矩阵撤销一次乘法，矩阵的幂记录同一矩阵的反复作用。

行列式、迹和 Frobenius 内积把矩阵变成一个数。行列式是方阵对有向体积的缩放倍数，它非零恰好对应方阵可逆；由古典伴随还可以证明，方阵只要有一侧的逆，这个单侧逆就是逆矩阵。迹只累加对角元素，满足循环性。Frobenius 内积配对两个同形矩阵的全部元素，由它得到 Frobenius 范数。

张量把索引推广到任意多个。重排只改变元素的位置，张量积与 Kronecker 积保留各因子的全部轴，缩约沿指定的轴求和；内积、矩阵乘法与迹都是缩约的特例。

本章出现了好几种“乘积”，它们的区别在于对索引做什么：有的配对后求和，有的在同一位置相乘而不求和，有的把两组索引全部保留。表 1.1按这一区别汇总它们的形状条件与输出。遇到一个乘积记号时，先看它消去哪些索引、保留哪些索引，再判断输出的形状与含义。

本章只把这些数组当作具体的数表。第 2章讨论它们记录的是什么：同一个对象换一组方向后坐标怎样改变，矩阵怎样记录线性映射。一般空间中的大小、夹角与正交在第 3章讨论。矩阵乘法的结合律、逆矩阵和幂在后文反复出现：矩阵反复作用的长期行为在第 8章讨论，误差经过一次矩阵作用被放大多少在第 7章讨论，方程的解与求解方法从第 9章开始讨论。

运算	形状条件与输出	索引作用
$\langle \boldsymbol{x}, \boldsymbol{y} \rangle$	两个 n 维向量，输出标量	配对后汇总
$\boldsymbol{AB}$	$(m \times n)(n \times p) \to m \times p$	汇总共同索引
$\boldsymbol{A} \odot \boldsymbol{B}$	同为 $m \times n$，输出仍为 $m \times n$	同位置相乘，不求和
$\boldsymbol{x} \otimes \boldsymbol{y}$	m 维与 n 维向量 $\to m \times n$	保留两条轴，不求和
$\boldsymbol{A} \otimes \boldsymbol{B}$	$(m \times n)$ 与 $(p \times q) \to (mp) \times (nq)$	保留两组成对索引
缩约	被缩约的各对轴长度相同	消去指定轴，保留其余轴

表 1.1　本章各种乘积的形状。同一类乘积记号可能对应不同操作：先看消去哪些索引，再判断输出的形状和含义。

第 2 章

线性空间、映射与坐标

第 1章把数据记成数组，并规定了数组的运算，但没有区分数组本身和它记录的对象。以仿射函数 $f_{a,b}(t) = a + bt$ 为例。它是一个函数，两个仿射函数相加或缩放后仍是仿射函数。选定 1 与 t 这两个基本函数以后，$f_{a,b}$ 才记成一列数 $(a, b)^{\top}$；换一组基本函数，这列数随之改变，函数本身却不变。

矩阵同样有两重身份。设计矩阵 $\boldsymbol{X}_{\epsilon}$（式 (1.2)）是一张 3×2 的数表，它还记录了一个作用：把两个系数送到三个拟合值。要在不同的记录之间换算，又不被记录方式误导，就要把对象和记录对象的数分开。

本章按这一区分展开。记录之前，先要说清对象在什么范围内作线性组合：第 2.1节把数组、函数等能相加和缩放的对象统一为线性空间，并研究其中对线性组合封闭的子空间，以及“有意忽略一个子空间中的差别”得到的商空间。第 2.2节在空间中选定一组基，用张成与线性无关保证每个对象有唯一的一组系数，即坐标；基的个数给出维数，换基时坐标按可逆矩阵换算，对象本身不变。

对象记录清楚以后，再记录对象之间保持线性组合的作用。第 2.3节说明，选定两端的基，线性映射就记成矩阵；核与像分别描述映射消去的输入和能到达的输出；换基改变矩阵而不改变映射，由此得到相抵与相似两种关系。第 2.4节讨论把向量线性地读成一个数的规则，即线性泛函，并说明转置记录的是“把输出端的读取传回输入端”。

本章在实数域上展开，涉及复数时另作说明。全章只用加法和数乘，所需的矩阵运算都来自第 1章；长度、收敛与正交由第 3章引入。

2.1 线性空间与子空间

第 1章的数组和本章开头的仿射函数都能相加和缩放。用一组方向记录这些对象之前，要先说清线性组合在什么范围内进行。本节先给出线性空间的定义，再讨论空间内部对线性组合封闭的部分，即子空间，以及子空间之间的比较、合并和商空间。

2.1.1 线性空间的定义与示例

第 1.1.2.3节验证过，同形数组的加法与数乘满足八条运算规则。其他对象也满足同样的规则：平面上的位移可以首尾相接，有限信号可以按幅度放大，多项式可以逐点相加。后面关于分解、方程的解和维数的结论只用到这八条规则，与对象具体是数组、位移、信号还是多项式无关。

因此，把带有这样的加法与数乘的集合统称为线性空间，其中的元素统称为向量。从此，“向量”指可以作线性组合的对象，不再要求它是一列数。

定义 2.1　实线性空间　设 V 是一个集合，给定加法（任意 $\boldsymbol{u},\boldsymbol{v}\in V$ 对应 $\boldsymbol{u}+\boldsymbol{v}\in V$）与实数数乘（任意 $a\in\mathbb{R}$、$\boldsymbol{u}\in V$ 对应 $a\boldsymbol{u}\in V$）。若对任意 $\boldsymbol{u},\boldsymbol{v},\boldsymbol{w}\in V$ 和 $a,b\in\mathbb{R}$，下面八条规则成立，就称 V 为**向量空间**（也称线性空间，vector space）：

1. 加法交换律：$\boldsymbol{u}+\boldsymbol{v}=\boldsymbol{v}+\boldsymbol{u}$。
2. 加法结合律：$(\boldsymbol{u}+\boldsymbol{v})+\boldsymbol{w}=\boldsymbol{u}+(\boldsymbol{v}+\boldsymbol{w})$。
3. 零元：存在 $\mathbf{0}\in V$，使 $\boldsymbol{u}+\mathbf{0}=\boldsymbol{u}$ 对每个 $\boldsymbol{u}$ 成立。
4. 加法逆元：每个 $\boldsymbol{u}$ 都有 $-\boldsymbol{u}\in V$，使 $\boldsymbol{u}+(-\boldsymbol{u})=\mathbf{0}$。
5. 数乘结合律：$a(b\boldsymbol{u})=(ab)\boldsymbol{u}$。
6. 数乘对数的分配律：$(a+b)\boldsymbol{u}=a\boldsymbol{u}+b\boldsymbol{u}$。
7. 数乘对向量的分配律：$a(\boldsymbol{u}+\boldsymbol{v})=a\boldsymbol{u}+a\boldsymbol{v}$。
8. 单位数乘：$1\boldsymbol{u}=\boldsymbol{u}$。

定义包含两层要求。第一层是封闭：加法和数乘的结果必须留在 V 中，否则运算无法在 V 内进行。第二层是规则：前四条说加法像数的加法一样可以交换、结合，有零元和相反元；后四条说数乘与加法按熟悉的方式配合。

有了这些规则，有限次线性运算无论怎样加括号、怎样展开，结果都相同。所以对任意 $\boldsymbol{v}_1,\dots,\boldsymbol{v}_k\in V$ 与实数 $a_1,\dots,a_k$，加权和 $\sum_{j=1}^{k}a_j\boldsymbol{v}_j$ 有确定的意义。它仍称为这组向量的线性组合，与第 1.1.2节对数组的定义一致。

标量也可以取复数。复线性空间满足同样的八条规则，只是数乘允许任意复数。允许哪些标量会改变线性结构。$\mathbb{C}$ 作为复线性空间时，每个元素都是 1 的复数倍；只允许实数数乘时，表示 $a+b\mathrm{i}$ 需要 1 与 i 两个方向。复数域上的基与线性映射按同样的方式定义，内积则要处理共轭。本章其余推导在实数域中进行。

常见的具体空间都满足定义。$\mathbb{R}^d$ 与全体 $m\times d$ 实矩阵在逐项运算下是线性空间，第 1.1.2.3节已逐条验证。次数不超过 k 的实多项式组成的集合

$$P_k=\{a_0+a_1t+\cdots+a_kt^k\ :\ a_0,\dots,a_k\in\mathbb{R}\}$$

在逐点相加与数乘下也是线性空间：两个这样的多项式相加或乘以实数，次数仍不超过 k；八条规则则逐点继承实数运算的规则。本章开头的仿射函数全体正是 P_1。

并非每个由向量组成的集合都是线性空间。下面两个 $\mathbb{R}^d$ 的子集沿用 $\mathbb{R}^d$ 的运算，分别破坏了加法封闭与数乘封闭。

示例 2.2　反例：仿射约束集与非负向量集　考虑第一坐标固定为 1 的向量与各坐标都非负的向量：

$$S_1 = \{\boldsymbol{x} \in \mathbb{R}^d : x_1 = 1\}$$
$$S_2 = \{\boldsymbol{x} \in \mathbb{R}^d : x_j \geq 0,\ j = 1, \dots, d\},$$

两者都沿用 $\mathbb{R}^d$ 的逐项加法与数乘。

S_1 的问题出在加法上。任取 $\boldsymbol{x}, \boldsymbol{y} \in S_1$，和的第一坐标是 $x_1 + y_1 = 2 \neq 1$，所以 $\boldsymbol{x} + \boldsymbol{y}$ 已经离开 S_1；同样，零向量的第一坐标为 0，S_1 连零向量都不含。S_2 则相反：两个非负向量相加仍然非负，加法没有问题，但数乘允许负数。$\boldsymbol{e}_1$ 属于 S_2，乘以 -1 后第一坐标变成 -1，就不在 S_2 中了。

所以 S_1 对加法不封闭，S_2 对数乘不封闭，二者都不是线性空间。两种失败分别对应定义中两种运算的封闭要求。

可见，判断一个集合是不是线性空间，要逐项检查运算是否封闭、规则是否成立，不能只看集合的形状。

2.1.2 子空间、和与直和

线性空间中常有一部分元素自己构成线性空间，例如平面中过原点的直线、齐次方程组的全部解。后面要处理的许多对象都是这样的部分：一组方向能到达的对象、一个映射消去的输入、方程的解，一般都只占空间的一部分。下面先给出判定条件，再比较和合并这些部分。

子空间的判定　设 U 是 V 的非空子集。若 U 对线性组合封闭，即对任意 $\boldsymbol{u}, \boldsymbol{v} \in U$ 和 $a, b \in \mathbb{R}$ 都有 $a\boldsymbol{u} + b\boldsymbol{v} \in U$，就称 U 为 V 的**线性子空间**（linear subspace），简称子空间。

这一条件已足以保证 U 在 V 的运算下构成线性空间。取 $a = b = 1$ 得加法封闭，取 $b = 0$ 得数乘封闭；取 $a = b = 0$ 得 $\mathbf{0} \in U$，取 $a = -1$、$b = 0$ 得 $-\boldsymbol{u} \in U$。其余规则对 V 的全部元素成立，自然也对 U 的元素成立。所以判断子空间只需检查这一条封闭条件，不必逐条核对八条规则。

每个空间都有两个平凡子空间：只含零向量的 $\{\mathbf{0}\}$ 和 V 本身。下面用判定条件检查三个常见集合。

示例 2.3　过原点的直线、平移的直线与齐次解集　取平面中的非零向量 $\boldsymbol{u}$、不在直线 $\{c\boldsymbol{u} : c \in \mathbb{R}\}$ 上的点 $\boldsymbol{p}$，以及矩阵 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$，考察下面三个集合：

$$L_0 = \{c\boldsymbol{u} : c \in \mathbb{R}\}, \qquad L_1 = \{\boldsymbol{p} + c\boldsymbol{u} : c \in \mathbb{R}\},$$
$$N = \{\boldsymbol{x} \in \mathbb{R}^d : \boldsymbol{A}\boldsymbol{x} = \mathbf{0}\}.$$

对 L_0 和 N，只需检查线性组合是否留在集合内。L_0 中任意两个元素 $c_1\boldsymbol{u}$ 与 $c_2\boldsymbol{u}$ 的组合是 $a(c_1\boldsymbol{u}) + b(c_2\boldsymbol{u}) = (ac_1 + bc_2)\boldsymbol{u}$，仍是 $\boldsymbol{u}$ 的倍数。N 中任取两个解 $\boldsymbol{x}, \boldsymbol{y}$，由式 (1.6)，

$$\boldsymbol{A}(a\boldsymbol{x} + b\boldsymbol{y}) = a\boldsymbol{A}\boldsymbol{x} + b\boldsymbol{A}\boldsymbol{y} = \mathbf{0},$$

所以组合 $a\boldsymbol{x} + b\boldsymbol{y}$ 仍是解。两者都是子空间。

L_1 在第一步就不满足要求：子空间必含零向量，而 L_1 不含。若 $\boldsymbol{p} + c\boldsymbol{u} = \mathbf{0}$，则 $\boldsymbol{p} = -c\boldsymbol{u}$ 落在 L_0 上，与 $\boldsymbol{p}$ 的取法矛盾。因此同一个方向 $\boldsymbol{u}$ 给出的直线，过原点时是子空间，平移离开原点后就不是了。

L_1 由子空间 L_0 沿 $\boldsymbol{p}$ 平移得到。示例 2.2中的约束集 $S_1 = \{\boldsymbol{x} : x_1 = 1\}$ 也是如此：它由齐次解集 $\{\boldsymbol{x} : x_1 = 0\}$ 沿 $\boldsymbol{e}_1$ 平移得到，是一个仿射集合，同样不是子空间。

同一个空间 V 中的几个子空间可以从四个方面比较：一个是否含于另一个，二者有哪些公共向量，合起来能到达哪里，合并后的分解是否唯一。这四个方面分别由包含、交、和与直和描述。它们只涉及线性组合，不涉及长度或夹角。

包含　若子空间 U 的每个元素都属于子空间 W，就记 $U \subseteq W$。这时 U 在 W 中对线性组合封闭，因而也是 W 的子空间。包含只比较两个集合的范围；两个子空间的“大小”要等下一节定义了维数才能比较。

交　两个子空间 $U, W \subseteq V$ 的交 $U \cap W$ 由同时属于二者的元素组成。它仍是子空间：若 $\boldsymbol{x}, \boldsymbol{y} \in U \cap W$，则二者同在 U 中，也同在 W 中，所以 $a\boldsymbol{x} + b\boldsymbol{y}$ 同属两边。任何同时含于 U 与 W 的子空间，其元素都属于交，所以交是同时含于二者的最大子空间。

在平面中，两条重合的过原点直线的交是整条直线，两条不同的过原点直线的交只有零向量。交为零只说明两个子空间没有公共的非零向量，不

说明二者合起来能到达整个空间。例如 $\mathbb{R}^3$ 中两条不同的过原点直线交为零，合起来只能到达一个平面。

当 U, W 分别由齐次线性方程组描述时，交就是同时满足两组方程的解集合。例如 $U = \{\boldsymbol{x} : x_1 = 0\}$ 与 $W = \{\boldsymbol{x} : x_2 = 0\}$ 的交是 $\{\boldsymbol{x} : x_1 = x_2 = 0\}$。求交因此化为解联立的齐次方程组，可以用第 1.2.7节的消元求出；解集的系统讨论见第 9章。

和 把两个子空间中的向量相加，能得到的全部向量组成和空间

$$U + W = \{\boldsymbol{u} + \boldsymbol{w} : \boldsymbol{u} \in U,\ \boldsymbol{w} \in W\}.$$

它对线性组合封闭：

$$a(\boldsymbol{u}_1 + \boldsymbol{w}_1) + b(\boldsymbol{u}_2 + \boldsymbol{w}_2) = (a\boldsymbol{u}_1 + b\boldsymbol{u}_2) + (a\boldsymbol{w}_1 + b\boldsymbol{w}_2),$$

右端两个括号分别属于 U 与 W。任何同时包含 U 与 W 的子空间都必须含有每个 $\boldsymbol{u} + \boldsymbol{w}$，所以 $U + W$ 是同时包含二者的最小子空间。

同时包含 U 与 W 的最小集合是并集 $U \cup W$，但并集一般对加法不封闭，不能代替和空间。

示例 2.4　反例：两条坐标轴的并 平面上的两条坐标轴 $U = \{(s,0)^{\mathsf{T}} : s \in \mathbb{R}\}$ 与 $W = \{(0,s)^{\mathsf{T}} : s \in \mathbb{R}\}$ 都是子空间。它们的并 $U \cup W$ 含有 $\boldsymbol{e}_1$ 与 $\boldsymbol{e}_2$，却不含二者之和：$\boldsymbol{e}_1 + \boldsymbol{e}_2 = (1,1)^{\mathsf{T}}$ 的两个坐标都不为零，既不在 U 中，也不在 W 中。

所以 $U \cup W$ 对加法不封闭，不是子空间。要得到子空间，必须补入所有形如 $(s,0)^{\mathsf{T}} + (0,t)^{\mathsf{T}}$ 的向量，结果是整个平面，即 $U + W = \mathbb{R}^2$。

和空间就是在并集之外补入了 $\boldsymbol{u} + \boldsymbol{w}$ 这类必需的线性组合。

直和与补空间 和空间中的向量都能写成 $\boldsymbol{u} + \boldsymbol{w}$，但写法未必唯一。在平面上取两条不平行的过原点直线，每个向量都能拆成分别落在两条直线上的两部分，而且拆法唯一。唯一与否由两个子空间的交决定。

定理 2.5　和的分解唯一的条件 设 U, W 是 V 的子空间。$U + W$ 中每个向量写成 $\boldsymbol{u} + \boldsymbol{w}$（$\boldsymbol{u} \in U$，$\boldsymbol{w} \in W$）的方式都唯一，当且仅当

$$U \cap W = \{\boldsymbol{0}\}.$$

证明　充分性：若 $\boldsymbol{u}_1+\boldsymbol{w}_1=\boldsymbol{u}_2+\boldsymbol{w}_2$，移项得 $\boldsymbol{u}_1-\boldsymbol{u}_2=\boldsymbol{w}_2-\boldsymbol{w}_1$。左边在 U 中，右边在 W 中，所以这个向量属于 $U\cap W$，只能是零。于是 $\boldsymbol{u}_1=\boldsymbol{u}_2$，$\boldsymbol{w}_1=\boldsymbol{w}_2$。

必要性：若交中有非零向量 $\boldsymbol{z}$，则 $\boldsymbol{z}\in U$、$-\boldsymbol{z}\in W$，等式 $\boldsymbol{0}=\boldsymbol{0}+\boldsymbol{0}=\boldsymbol{z}+(-\boldsymbol{z})$ 给出零向量的两种不同分解，唯一性不成立。 ■

满足 $U\cap W=\{\boldsymbol{0}\}$ 时，称和 $U+W$ 为**直和**（direct sum），记为 $U\oplus W$。唯一分解不要求两个子空间互相垂直：平面中任意两条不平行的过原点直线都构成直和。

若还有 $U+W=V$，就写 $V=U\oplus W$，并称 W 为 U 在 V 中的**补空间**（complement）。补空间一般不唯一：平面中一条过原点的直线，以任何不平行于它的过原点直线为补空间。

补空间总是存在，证明要用到下一节的基扩充（第 2.2.2节）。

2.1.3 商空间

和与直和把子空间合并起来。有时需要反过来，有意忽略某个子空间内的差别。例如只关心仿射函数 $f_{a,b}(t)=a+bt$ 在 $t=0$ 处的值，即截距 a 时，$f_{a,b}$ 与 $f_{a,b'}$ 没有区别；二者之差 $(b-b')t$ 落在子空间 $\{st:s\in\mathbb{R}\}$ 中。

非齐次约束 $x_1=1$ 的解也有同样的结构。它的解集合 $\{\boldsymbol{e}_1+\boldsymbol{n}:n_1=0\}$ 由一个特解加上齐次解子空间 $\{\boldsymbol{n}:n_1=0\}$ 中的全部向量组成，任意两个解之差都落在这个子空间里。两个例子的共同点是：相差某个子空间中的向量，就视为相同。

把这一点写成关系。设 U 是 V 的子空间，规定 $\boldsymbol{x}\sim\boldsymbol{y}$ 当且仅当 $\boldsymbol{x}-\boldsymbol{y}\in U$。它是一个等价关系，即同时满足自反、对称与传递三条性质的关系；等价关系及其等价类划分可参考卷一第 1 章“集合、关系与映射”。三条性质逐一验证如下：由 $\boldsymbol{x}-\boldsymbol{x}=\boldsymbol{0}\in U$ 得自反性；由 $\boldsymbol{x}-\boldsymbol{y}\in U$ 蕴含 $\boldsymbol{y}-\boldsymbol{x}\in U$ 得对称性；由 $(\boldsymbol{x}-\boldsymbol{y})+(\boldsymbol{y}-\boldsymbol{z})=\boldsymbol{x}-\boldsymbol{z}\in U$ 得传递性。

$\boldsymbol{x}$ 所在的等价类为

$$\boldsymbol{x}+U=\{\boldsymbol{x}+\boldsymbol{n}:\boldsymbol{n}\in U\},$$

即子空间 U 沿 $\boldsymbol{x}$ 平移所得的集合。两个类相等，不要求代表元相等，只要求代表元之差落在 U 中。全部等价类把 V 分成互不重叠的块。图 2.1在平面上画出这种划分：U 是 x 轴，每条平行于 x 轴的直线是一个等价类。

要让这些类像向量一样相加和缩放，自然的做法是对代表元作运算。

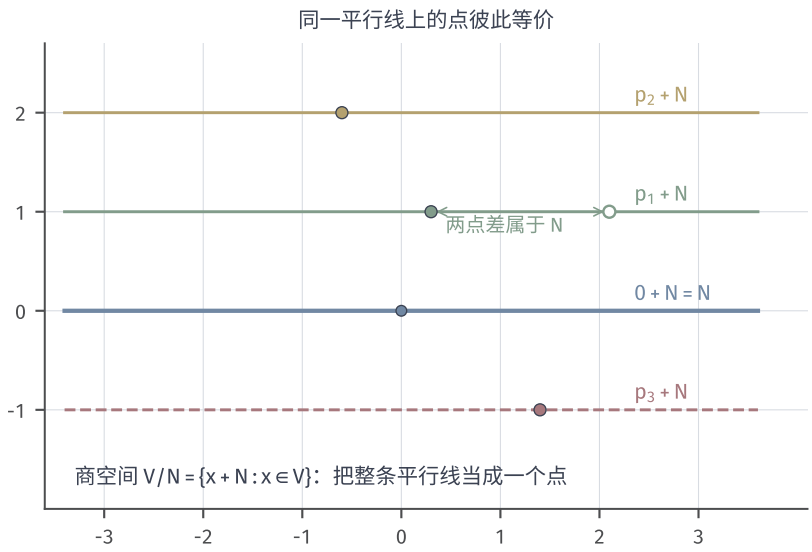


图 2.1 商空间的等价类。$V=\mathbb{R}^2$，子空间 U 为 x 轴（蓝线 $0+U$）；每条平行直线 $p+U=\{(x,p_y)\}$ 是一个等价类，图中画出 $y=1$（绿）、$y=2$（黄）、$y=-1$（红虚线）。绿线上实点 $(0.3,1)$ 与空心点 $(2.1,1)$ 之差 $(1.8,0)\in U$，故属同一类；商空间 V/U 把每条平行线当成一个点。

定义 2.6 商空间 设 U 是线性空间 V 的子空间。全部等价类 $\boldsymbol{x}+U$ 组成的集合记为 V/U，规定

$$(\boldsymbol{x}+U)+(\boldsymbol{y}+U)=(\boldsymbol{x}+\boldsymbol{y})+U$$
$$a(\boldsymbol{x}+U)=a\boldsymbol{x}+U,$$

称 V/U 为 V 对 U 的**商空间**（quotient space）。

借代表元定义运算，必须先检查结果与代表元的选取无关。把代表元换成 $\boldsymbol{x}'=\boldsymbol{x}+\boldsymbol{n}_1$、$\boldsymbol{y}'=\boldsymbol{y}+\boldsymbol{n}_2$（$\boldsymbol{n}_1,\boldsymbol{n}_2\in U$）时，$\boldsymbol{x}'+\boldsymbol{y}'$ 与 $\boldsymbol{x}+\boldsymbol{y}$ 只相差 $\boldsymbol{n}_1+\boldsymbol{n}_2$，$a\boldsymbol{x}'$ 与 $a\boldsymbol{x}$ 只相差 $a\boldsymbol{n}_1$。二者都属于 U，所以得到的类不变。

零类是 U 本身，$\boldsymbol{x}+U$ 的相反类是 $-\boldsymbol{x}+U$，其余规则由 V 的运算规则逐条继承，所以 V/U 是线性空间。在图 2.1中，两条水平线相加就是高度相加：商空间只记录高度，忽略了沿 x 轴的位置。

商空间的元素是整条平行线，而不是从每条线上挑出的某个代表点。若在每条水平线上都取它与 y 轴的交点作代表，就等于另选了一个补空间（y 轴）来记录各类；换成另一条过原点的非水平直线，代表点随之改变，类本身却不变。所以商空间描述的是“忽略 U 方向的差别以后剩下什么”，不依赖代表元或补空间的选择。

回到本节开头的截距问题，可以照此算出商空间的元素与运算。

示例 2.7　只保留截距的商空间　取 $V = P_1 = \{a + bt : a, b \in \mathbb{R}\}$，要忽略的差别是斜率，所以取子空间 $U = \{st : s \in \mathbb{R}\}$。先看一个类里有哪些函数。$f_{a,b} = a + bt$ 所在的类是

$$f_{a,b} + U = \{a + (b + s)t : s \in \mathbb{R}\} = \{a + rt : r \in \mathbb{R}\},$$

即截距为 a、斜率任意的全部仿射函数，它只依赖 a。由此也可以判断两个类何时相同：$f_{a,b} + U = f_{a',b'} + U$ 当且仅当 $f_{a,b} - f_{a',b'} = (a - a') + (b - b')t \in U$，即 $a = a'$。

再看运算。按商空间的定义，

$$(f_{a,b} + U) + (f_{a',b'} + U) = f_{a+a',\,b+b'} + U$$
$$c(f_{a,b} + U) = f_{ca,\,cb} + U,$$

结果中的截距是 $a + a'$ 与 ca，即截距分别相加、缩放。

于是规则 $f_{a,b} + U \mapsto a$ 是从 P_1/U 到 $\mathbb{R}$ 的双射，并且保持加法与数乘。商空间 P_1/U 恰好只记录截距，斜率的差别已被忽略。

商空间的维数在第 2.2.2节计算；它与线性映射的联系见第 2.3.2节。

2.2　基、维数与坐标

上一节规定了线性组合在什么范围内进行。本节用有限个数记录空间中的对象：选定一组方向，把对象写成它们的线性组合，再用组合系数代替对象。为此，先用张成与线性无关判断系数是否存在、是否唯一；两者同时成立的方向组称为基，基所含的向量个数就是空间的维数。最后定义基下的坐标，并推导换基时坐标怎样换算。

2.2.1　张成与线性无关

张成　在平面上，两个不共线方向的加权组合能取到每一个点；只有一个方向时，无论怎样加权，结果都停在过原点的一条直线上。为了描述一组方向能到达的范围，给它们的全部线性组合命名：给定 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_k \in V$，集合

$$\operatorname{span}\{\boldsymbol{v}_1, \dots, \boldsymbol{v}_k\} = \left\{ \sum_{j=1}^{k} a_j \boldsymbol{v}_j : a_j \in \mathbb{R} \right\} \tag{2.1}$$

称为这组向量的**张成空间**（span）。

两个线性组合再作线性组合，仍是这组向量的线性组合，所以张成空间对线性组合封闭，是 V 的子空间。任何包含 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_k$ 的子空间都必须含

有它们的全部线性组合，所以张成空间是包含这组向量的最小子空间。若 $\operatorname{span}\{\boldsymbol{v}_1,\dots,\boldsymbol{v}_k\}=V$，就说这组向量张成 V，也称它们是 V 的一个生成组。

在 $\mathbb{R}^m$ 中，把 $\boldsymbol{v}_1,\dots,\boldsymbol{v}_k$ 排成矩阵 $\boldsymbol{V}$ 的各列。按列读法，$\sum_j a_j\boldsymbol{v}_j=\boldsymbol{V}\boldsymbol{a}$，所以张成空间就是输出集合 $\{\boldsymbol{V}\boldsymbol{a}:\boldsymbol{a}\in\mathbb{R}^k\}$。图 2.2对比了两种情形：两个不共线方向的组合取遍整个平面，单个方向的组合只是一条直线。

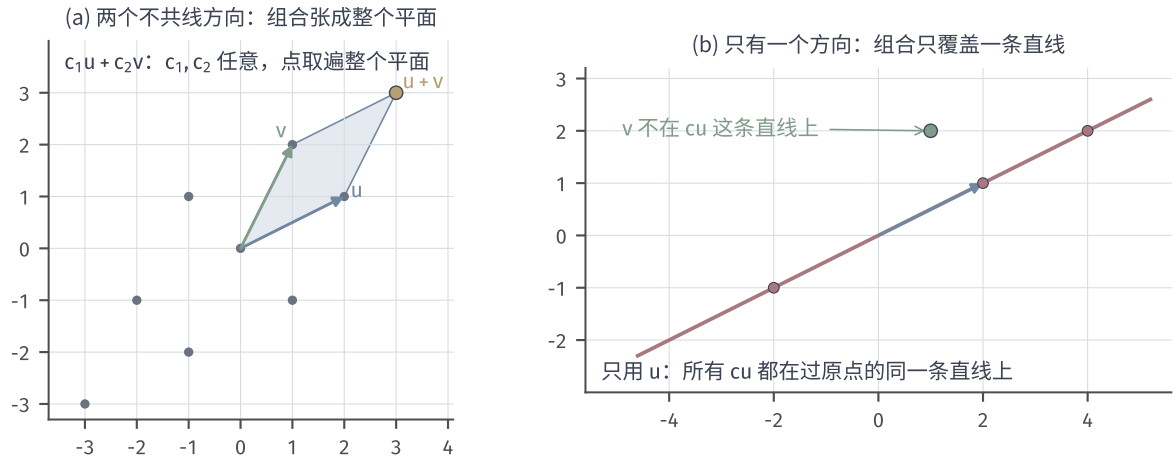


图 2.2　两个方向与一个方向的张成范围。左：$\boldsymbol{u}=(2,1)$（蓝箭头）与 $\boldsymbol{v}=(1,2)$（绿箭头）的全部加权组合取遍整个平面，浅蓝平行四边形标出 $0,\boldsymbol{u},\boldsymbol{u}+\boldsymbol{v},\boldsymbol{v}$，灰点为整数系数格点，黄点为 $\boldsymbol{u}+\boldsymbol{v}=(3,3)$。右：只有 $\boldsymbol{u}$ 一个方向时，组合 $\{c\boldsymbol{u}\}$ 只是过原点的一条直线（红线），$\boldsymbol{v}$ 不在其上。两图坐标等比例，为解析教学例。

线性无关　张成说明哪些对象能被表示，但没有说明表示方式是否只有一种。若同一个对象可以用两组不同的系数写出，某些方向就是多余的。两组系数相减，得到零向量的一个系数不全为零的表示。所以判断有无冗余，只需看零向量能否被非平凡地表示。若

$$a_1\boldsymbol{v}_1+\cdots+a_k\boldsymbol{v}_k=\boldsymbol{0} \tag{2.2}$$

仅在全部 $a_j=0$ 时成立，就称这组向量**线性无关**（linearly independent）；否则称为**线性相关**（linearly dependent），即存在不全为零的系数使式(2.2)成立。

线性相关时，挑出一个非零系数 a_j 并移项，就能把 $\boldsymbol{v}_j$ 写成其余向量的线性组合，这个方向没有带来新的可达范围。在 $\mathbb{R}^m$ 中，线性无关就是齐次方程 $\boldsymbol{V}\boldsymbol{a}=\boldsymbol{0}$ 只有零解。

贯穿例中设计矩阵的两列几乎同向。按定义检验，它们仍然线性无关。

示例 2.8　近共线的两列仍线性无关　式 (1.2)中的两列是 $\boldsymbol{c}_1 = (1,1,1)^{\mathsf{T}}$ 与 $\boldsymbol{c}_2 = \boldsymbol{c}_1 + \varepsilon\boldsymbol{q}$，其中 $\boldsymbol{q} = (0,1,-1)^{\mathsf{T}}$。$\boldsymbol{c}_2$ 由 $\boldsymbol{c}_1$ 沿 $\boldsymbol{q}$ 偏离一点得到，所以先确认 $\boldsymbol{c}_1$ 与 $\boldsymbol{q}$ 本身线性无关：$\alpha\boldsymbol{c}_1 + \beta\boldsymbol{q} = (\alpha,\ \alpha+\beta,\ \alpha-\beta)^{\mathsf{T}}$ 为零时，第一坐标给出 $\alpha = 0$，第二坐标再给出 $\beta = 0$。

再把两列的组合改写到 $\boldsymbol{c}_1, \boldsymbol{q}$ 上：

$$a_1\boldsymbol{c}_1 + a_2\boldsymbol{c}_2 = (a_1 + a_2)\boldsymbol{c}_1 + a_2\varepsilon\boldsymbol{q}.$$

它为零时，由 $\boldsymbol{c}_1, \boldsymbol{q}$ 线性无关，两个系数都须为零，即 $a_1 + a_2 = 0$ 与 $a_2\varepsilon = 0$。只要 $\varepsilon \neq 0$，第二式就迫使 $a_2 = 0$，进而 $a_1 = 0$，两列线性无关。只有 $\varepsilon = 0$ 时两列重合，$\boldsymbol{c}_1 - \boldsymbol{c}_2 = \boldsymbol{0}$，才线性相关。

因此，“几乎同向”与线性无关是两回事。线性无关是精确的是非判断，只要 $\varepsilon \neq 0$ 就成立。

表示的存在与唯一　张成与线性无关回答两个独立的问题：能表示哪些对象，以及表示是否冗余。下面的例子在平面上把二者分开。

示例 2.9　足够、不够与冗余的方向组　在 $\mathbb{R}^2$ 中取 $\boldsymbol{v}_1 = (1,0)^{\mathsf{T}}$、$\boldsymbol{v}_2 = (0,1)^{\mathsf{T}}$ 与 $\boldsymbol{v}_3 = (1,1)^{\mathsf{T}}$，比较三种方向组。

用 $\boldsymbol{v}_1, \boldsymbol{v}_2$ 两个方向时，$a_1\boldsymbol{v}_1 + a_2\boldsymbol{v}_2 = (a_1, a_2)^{\mathsf{T}}$，任一目标点 $(x,y)^{\mathsf{T}}$ 都能取到，而且系数只能是 $a_1 = x$、$a_2 = y$：方向既足够，又没有冗余。只用 $\boldsymbol{v}_1$ 时，组合 $a_1\boldsymbol{v}_1 = (a_1, 0)^{\mathsf{T}}$ 停在横轴上，连 $\boldsymbol{v}_2$ 都取不到：表示不一定存在。

三个方向一起用时，能到达的仍是整个平面，但同一个目标可以有不同的系数，例如

$$0\boldsymbol{v}_1 + 0\boldsymbol{v}_2 + 1\boldsymbol{v}_3 = (1,1)^{\mathsf{T}} = 1\boldsymbol{v}_1 + 1\boldsymbol{v}_2 + 0\boldsymbol{v}_3.$$

两组系数相减，得到零向量的非平凡表示 $\boldsymbol{v}_1 + \boldsymbol{v}_2 - \boldsymbol{v}_3 = \boldsymbol{0}$。这说明加入 $\boldsymbol{v}_3$ 没有扩大可达范围，只让表示失去了唯一性。

图 2.3把第三种情形下的两种表示画在同一个平面上。

例子中的现象是一般的。存在性来自张成：张成空间中的每个对象都有一组系数。唯一性来自线性无关：若同一对象有两组系数，二者相减得到式(2.2)形式的关系，线性无关迫使两组系数之差为零。

反过来，唯一性也蕴含线性无关。若某组不全为零的系数使线性组合为零，把这组系数加到某个对象的一组表示上，就得到同一对象的第二组表

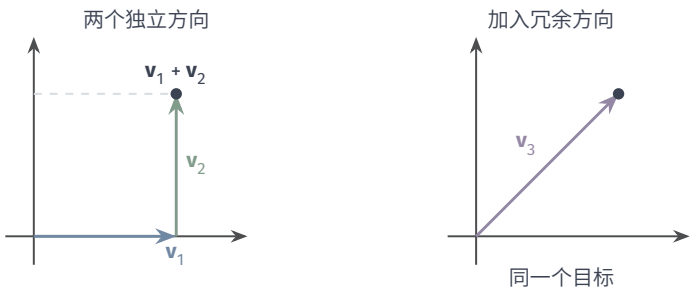


图 2.3 冗余方向与重复表示。取 $\boldsymbol{v}_1=(1,0)^{\mathsf{T}}$、$\boldsymbol{v}_2=(0,1)^{\mathsf{T}}$ 与 $\boldsymbol{v}_3=(1,1)^{\mathsf{T}}$。左图沿 $\boldsymbol{v}_1$ 再沿 $\boldsymbol{v}_2$，右图直接沿 $\boldsymbol{v}_3$，到达同一个目标；前两个向量已能表示平面中的每个向量，加入 $\boldsymbol{v}_3$ 只使生成组冗余。两图坐标等比例。

示。所以，“张成空间中每个对象的系数唯一”与“零向量只有平凡表示”是同一个条件。后面定义坐标正是以此为依据。

2.2.2 基与维数

张成保证表示存在，线性无关保证表示唯一。同时满足这两个条件的一组向量称为**基**（basis）：它能到达整个空间，又没有多余的方向，可以充当整个空间的一把“尺子”。

$\mathbb{R}^d$ 的标准坐标向量 $\boldsymbol{e}_1,\dots,\boldsymbol{e}_d$ 是一组基，称为标准基：$\boldsymbol{x}=\sum_j x_j\boldsymbol{e}_j$ 说明它们张成 $\mathbb{R}^d$，而 $\sum_j a_j\boldsymbol{e}_j=(a_1,\dots,a_d)^{\mathsf{T}}=\boldsymbol{0}$ 迫使全部 $a_j=0$。P_k 中的 $1,t,\dots,t^k$ 也是一组基：每个多项式都是它们的组合，组合为零多项式时各项系数都为零。

子空间也有基。下面为一个齐次方程的解集合求出一组基。

示例 2.10　齐次方程解平面的一组基　设 N 是 $\mathbb{R}^3$ 中齐次方程 $x_1+2x_2+3x_3=0$ 的解集合；由示例 2.3，N 是子空间。方程只约束了 x_1：解满足 $x_1=-2x_2-3x_3$，而 x_2,x_3 可以任取。把每个解按这两个自由坐标拆开，

$$\boldsymbol{x}=x_2(-2,1,0)^{\mathsf{T}}+x_3(-3,0,1)^{\mathsf{T}},$$

可见 $\boldsymbol{n}_1=(-2,1,0)^{\mathsf{T}}$ 与 $\boldsymbol{n}_2=(-3,0,1)^{\mathsf{T}}$ 张成 N。

还要检查这两个方向没有冗余。若 $a\boldsymbol{n}_1+b\boldsymbol{n}_2=(-2a-3b,\,a,\,b)^{\mathsf{T}}=\boldsymbol{0}$，第二、三个坐标直接给出 $a=b=0$，所以二者线性无关。于是 $\boldsymbol{n}_1,\boldsymbol{n}_2$ 是 N 的一组基：两个自由坐标各对应一个基向量。

基的抽取与扩充　若 V 有一个有限的生成组，就称 V 是有限维的；本章只讨论有限维空间。有限维空间总有基，可以从两个方向得到。

第一种做法是抽取。从任一有限生成组出发，若某个成员能写成其余向量的线性组合，删去它不会缩小张成范围。反复删除，直到剩下的向量中没有一个能由其余向量表示。这时剩下的向量线性无关，又仍张成 V，构成一组基。

第二种做法是扩充。从任一线性无关组出发，逐次加入不在其张成空间中的向量。每加入一个新向量，张成范围严格扩大，新组仍线性无关。理由如下：若新组的某个组合为零，新向量的系数必为零，否则新向量能由原组表示，落在原张成空间中；新向量的系数为零以后，原组的线性无关性又使其余系数为零。

扩充不会无限进行下去。下文的交换引理（定理 2.11）说明，有限维空间中线性无关组的长度不超过任一生成组的长度，所以扩充必在有限步内停止。停止时张成空间之外再没有向量，所得的组就是基。

抽取把冗余的生成组压缩成基，扩充把线性无关组补足成基。后面的许多证明都会用到扩充。

维数　基的向量个数可以度量空间的大小，前提是换一组基时个数不变。这由交换引理保证。

定理 2.11　交换引理　若 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_r$ 线性无关，且每个 $\boldsymbol{u}_i$ 都属于 $\operatorname{span}\{\boldsymbol{v}_1, \dots, \boldsymbol{v}_s\}$，则 $r \le s$；并且这 r 个 $\boldsymbol{u}_i$ 可以逐个换入原生成组、换出同样多个 $\boldsymbol{v}_j$，每次换完新组仍张成原来的空间。

证明　从生成组 $G_0 = \{\boldsymbol{v}_1, \dots, \boldsymbol{v}_s\}$ 开始。因为 $\boldsymbol{u}_1 \in \operatorname{span} G_0$，它可写成若干 $\boldsymbol{v}_j$ 的组合。这些系数不全为零，否则 $\boldsymbol{u}_1 = \boldsymbol{0}$，与 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_r$ 线性无关矛盾。取某个系数非零的 $\boldsymbol{v}_j$，从这个表达式中把它解出，$\boldsymbol{v}_j$ 就能由 $\boldsymbol{u}_1$ 与其余的 $\boldsymbol{v}$ 表示。于是用 $\boldsymbol{u}_1$ 换出 $\boldsymbol{v}_j$，新组 G_1 与 G_0 张成同一个空间。

一般地，设第 $i-1$ 步后的组 G_{i-1} 由 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_{i-1}$ 和 $s-(i-1)$ 个留下的 $\boldsymbol{v}$ 组成，且与 G_0 张成同一空间。于是 $\boldsymbol{u}_i \in \operatorname{span} G_{i-1}$。若 $\boldsymbol{u}_i$ 只用 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_{i-1}$ 就能表示，就违反线性无关；所以表达式中至少有一个留下的 $\boldsymbol{v}$ 系数非零。把它解出并换入 $\boldsymbol{u}_i$，张成范围不变。只要还有留下的 $\boldsymbol{v}$，这一步就能继续。

若 $r > s$，换满 s 次以后组内只剩 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_s$，而 $\boldsymbol{u}_{s+1}$ 属于 $\operatorname{span} G_s = \operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_s\}$，与 r 个 $\boldsymbol{u}$ 线性无关矛盾。故 $r \le s$，上面的逐次交换就是定理所说的换入换出过程。 ■

由交换引理，基的向量个数与基的选取无关。任取两组基，设个数分别为 r 与 s。把第一组看成线性无关组、第二组看成生成组，得 $r \le s$；互换两组的角色，又得 $s \le r$，所以 $r = s$。这个共同的个数称为空间的**维数**（dimension），记为 $\dim V$。只含零向量的空间以空集为基，维数为 0。

交换引理的论证依赖有限的生成组，所以后面的基扩充与维数计算都限于有限维空间，不能直接用于无限维的函数展开。

2.2.3 子空间的维数与分解

有了维数，就能比较子空间的大小。若 $U \subseteq W$，取 U 的一组基，它在 W 中仍线性无关，可以按上一小节的方法扩充成 W 的基。扩充只增加向量，所以 $\dim U \le \dim W$；新增向量的个数恰为 $\dim W - \dim U$，它表示 U 之外还有多少个独立方向。

若同时有 $\dim U = \dim W$，把 U 的基扩充成 W 的基不需要新增向量，即 U 的基已经张成 W，所以 $U = W$。这里的包含条件不能省略，仅凭维数相同推不出包含。

> **示例 2.12　反例：同维而互不包含的两条直线**　在 $\mathbb{R}^2$ 中取横轴 $U = \{(s,0)^{\mathsf T} : s \in \mathbb{R}\}$ 与对角线 $W = \{(s,s)^{\mathsf T} : s \in \mathbb{R}\}$。二者分别以 $\boldsymbol{e}_1$ 与 $(1,1)^{\mathsf T}$ 为基，所以 $\dim U = \dim W = 1$。然而 $\boldsymbol{e}_1$ 的两个坐标不相等，不在 W 中；$(1,1)^{\mathsf T}$ 的第二坐标不为零，也不在 U 中。
>
> 两条直线维数相同，却互不包含。维数只数方向的个数，不记录这些方向指向哪里，所以上面的结论必须以 $U \subseteq W$ 为前提。

“先取已有的基，再补新方向”这一做法，下面计算和空间、补空间与商空间时都会用到，后面的秩零度定理也以它为证明思路。

和空间　两个子空间的公共方向在两边各计一次，所以和空间的维数一般小于两边维数之和。下面从交的一组基出发，算出准确的公式。

设 $\boldsymbol{z}_1, \dots, \boldsymbol{z}_k$ 是 $U \cap W$ 的一组基，把它扩充为 U 的基 $\boldsymbol{z}_1, \dots, \boldsymbol{z}_k, \boldsymbol{u}_1, \dots, \boldsymbol{u}_p$，再另行扩充为 W 的基 $\boldsymbol{z}_1, \dots, \boldsymbol{z}_k, \boldsymbol{w}_1, \dots, \boldsymbol{w}_q$。我们说明这 $k+p+q$ 个向量构成 $U + W$ 的基。

每个 $\boldsymbol{u} + \boldsymbol{w}$（$\boldsymbol{u} \in U$，$\boldsymbol{w} \in W$）都是这些向量的组合，所以它们张成 $U + W$。为证线性无关，设

$$\sum_i \alpha_i \boldsymbol{z}_i + \sum_j \beta_j \boldsymbol{u}_j + \sum_l \gamma_l \boldsymbol{w}_l = \boldsymbol{0}.$$

移项得 $\sum_l \gamma_l \boldsymbol{w}_l = -\sum_i \alpha_i \boldsymbol{z}_i - \sum_j \beta_j \boldsymbol{u}_j$。左边属于 W，右边属于 U，所以这个向量属于 $U \cap W$，可以写成 $\sum_i \delta_i \boldsymbol{z}_i$。于是 $\sum_l \gamma_l \boldsymbol{w}_l - \sum_i \delta_i \boldsymbol{z}_i = \boldsymbol{0}$，由

W 的基线性无关，全部 $\gamma_l = 0$。代回原式，再由 U 的基线性无关，全部 α_i 与 β_j 也为零。

因此 $\dim(U+W) = k+p+q = (k+p)+(k+q)-k$，即

$$\dim(U+W) = \dim U + \dim W - \dim(U \cap W). \tag{2.3}$$

减去的是两边重复计入的公共方向的个数，不是两个集合元素个数之差。下面在 $\mathbb{R}^3$ 中核对这一公式。

示例 2.13　两个坐标平面的和　在 $\mathbb{R}^3$ 中取两个坐标平面 $U = \operatorname{span}\{\boldsymbol{e}_1, \boldsymbol{e}_2\}$ 与 $W = \operatorname{span}\{\boldsymbol{e}_2, \boldsymbol{e}_3\}$，维数都是 2。先求交：$U$ 由第三坐标为零的向量组成，W 由第一坐标为零的向量组成，同时满足两条的向量只剩第二坐标，所以 $U \cap W = \operatorname{span}\{\boldsymbol{e}_2\}$，维数为 1。再看和：$U+W$ 含有 $\boldsymbol{e}_1, \boldsymbol{e}_2, \boldsymbol{e}_3$，所以就是 $\mathbb{R}^3$。两边与公式相符：

$$\dim(U+W) = 3 = 2 + 2 - 1.$$

减去的 1 正是两个平面共有的 $\boldsymbol{e}_2$ 方向，它在 $\dim U$ 与 $\dim W$ 中各计了一次。

作为对照，改取两条坐标轴 $U' = \operatorname{span}\{\boldsymbol{e}_1\}$、$W' = \operatorname{span}\{\boldsymbol{e}_2\}$。它们没有公共的非零向量，交为零，于是 $\dim(U'+W') = 1+1-0 = 2$：交为零时，和的维数等于两边维数之和。

补空间　第 2.1.2节定义了补空间，现在用基扩充证明它总存在。把 U 的基扩充为 V 的基，新增向量张成的子空间记为 W。整组基张成 V，所以 $U+W = V$。若某个向量同属 U 与 W，它既是 U 的基向量的组合，又是新增向量的组合；两种写法相减，得到整组基的一个组合为零，所以系数全为零，该向量为零。于是 $U \cap W = \{\mathbf{0}\}$，$V = U \oplus W$。

由维数公式，直和时交的维数为零，所以 $\dim V = \dim U + \dim W$。扩充的方式不唯一，补空间也就不唯一，这与平面中直线的例子一致。

商空间　同样的扩充也给出第 2.1.3节商空间的维数。取 U 的一组基 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_s$，扩充为 V 的基 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_s, \boldsymbol{w}_1, \dots, \boldsymbol{w}_t$。新增向量的类 $\boldsymbol{w}_1 + U, \dots, \boldsymbol{w}_t + U$ 张成 V/U：任一 $\boldsymbol{x}$ 写成整组基的组合，其中属于 U 的部分落进零类而消去。

这些类也线性无关。若 $\sum_j a_j(\boldsymbol{w}_j + U) = U$，则 $\sum_j a_j \boldsymbol{w}_j \in U$，它能由 $\boldsymbol{u}_i$ 表示，整组基的线性无关性迫使全部 $a_j = 0$。因此

$$\dim(V/U) = \dim V - \dim U. \tag{2.4}$$

商空间的维数等于补空间的维数，二者的关系还可以说得更具体。新增向量 $\boldsymbol{w}_j$ 张成 U 的一个补空间 W，每个 $\boldsymbol{x}$ 唯一分解为 $\boldsymbol{x}=\boldsymbol{u}+\boldsymbol{w}$（$\boldsymbol{u}\in U$，$\boldsymbol{w}\in W$），于是类 $\boldsymbol{x}+U=\boldsymbol{w}+U$ 中的点都形如 $\boldsymbol{w}+\boldsymbol{u}'$（$\boldsymbol{u}'\in U$）。这样的点落在 W 中，当且仅当 $\boldsymbol{u}'\in U\cap W=\{\boldsymbol{0}\}$，所以每个类与 W 恰交于一点 $\boldsymbol{w}$。选定一个补空间，就是为每个类选定一个代表元。补空间需要选择，商空间不依赖任何选择，这是二者的区别。

在示例 2.7中，$\dim(P_1/U)=2-1=1$，商空间只剩截距这一个方向；在图 2.1中，$\dim(\mathbb{R}^2/U)=1$，只剩高度。

2.2.4 坐标与坐标变换

有了基，每个对象都有唯一的一组系数。本小节先把这组系数定义为坐标，说明它怎样代替对象参与计算；再看坐标的大小为什么不能直接反映对象的大小；最后推导换基时坐标的换算规则。

有序基下的坐标 固定有序基 $\mathcal{B}=(\boldsymbol{b}_1,\dots,\boldsymbol{b}_d)$ 后，对象 $\boldsymbol{v}$ 唯一写成 $\sum_{j=1}^{d}x_j\boldsymbol{b}_j$。系数列 $[\boldsymbol{v}]_{\mathcal{B}}=(x_1,\dots,x_d)^{\mathsf{T}}$ 称为 $\boldsymbol{v}$ 在基 $\mathcal{B}$ 下的**坐标**（coordinates）。

由于存在性来自张成、唯一性来自线性无关，坐标映射 $\boldsymbol{v}\mapsto[\boldsymbol{v}]_{\mathcal{B}}$ 是从 V 到 $\mathbb{R}^d$ 的双射：每个对象恰有一列坐标，每列实数 $(x_1,\dots,x_d)^{\mathsf{T}}$ 也恰好记录对象 $\sum_j x_j\boldsymbol{b}_j$。

坐标映射还保持线性组合。若 $[\boldsymbol{v}]_{\mathcal{B}}=\boldsymbol{x}$、$[\boldsymbol{w}]_{\mathcal{B}}=\boldsymbol{y}$，则 $a\boldsymbol{v}+b\boldsymbol{w}=\sum_j(ax_j+by_j)\boldsymbol{b}_j$，由唯一性得

$$[a\boldsymbol{v}+b\boldsymbol{w}]_{\mathcal{B}}=a\boldsymbol{x}+b\boldsymbol{y}.$$

因此，对象上的线性运算可以完全在坐标上进行，算完再按基还原。

在 $\mathbb{R}^d$ 中，把基向量排成矩阵 $\boldsymbol{B}=[\boldsymbol{b}_1\ \cdots\ \boldsymbol{b}_d]$。按列读法，$\boldsymbol{v}=\boldsymbol{B}[\boldsymbol{v}]_{\mathcal{B}}$，所以坐标就是方程 $\boldsymbol{B}\boldsymbol{x}=\boldsymbol{v}$ 的唯一解。下面用这个方程求一个斜基下的坐标。

示例 2.14　同一向量在两组基下的坐标 取 $\mathbb{R}^2$ 中的向量 $\boldsymbol{x}=(1,2)^{\mathsf{T}}$。在标准基 $(\boldsymbol{e}_1,\boldsymbol{e}_2)$ 下，$\boldsymbol{x}=1\cdot\boldsymbol{e}_1+2\cdot\boldsymbol{e}_2$，坐标就是 $(1,2)^{\mathsf{T}}$。改用斜基 $\mathcal{B}=(\boldsymbol{b}_1,\boldsymbol{b}_2)$，其中 $\boldsymbol{b}_1=(2,1)^{\mathsf{T}}$、$\boldsymbol{b}_2=(-1,1)^{\mathsf{T}}$，坐标 $(c_1,c_2)^{\mathsf{T}}$ 要由 $c_1\boldsymbol{b}_1+c_2\boldsymbol{b}_2=\boldsymbol{x}$ 解出，逐坐标写开就是

$$\begin{aligned}2c_1-c_2&=1\\ c_1+c_2&=2.\end{aligned}$$

两式相加消去 c_2，得 $3c_1 = 3$，所以 $c_1 = 1$，再代入第二式得 $c_2 = 1$。代回检验，$\boldsymbol{b}_1 + \boldsymbol{b}_2 = (1,2)^{\mathsf{T}}$ 正是 $\boldsymbol{x}$。

所以 $[\boldsymbol{x}]_{\mathcal{B}} = (1,1)^{\mathsf{T}}$。向量本身没有移动，只是换了一组基来度量，读数随之改变。

图 2.4画出这两种读法。

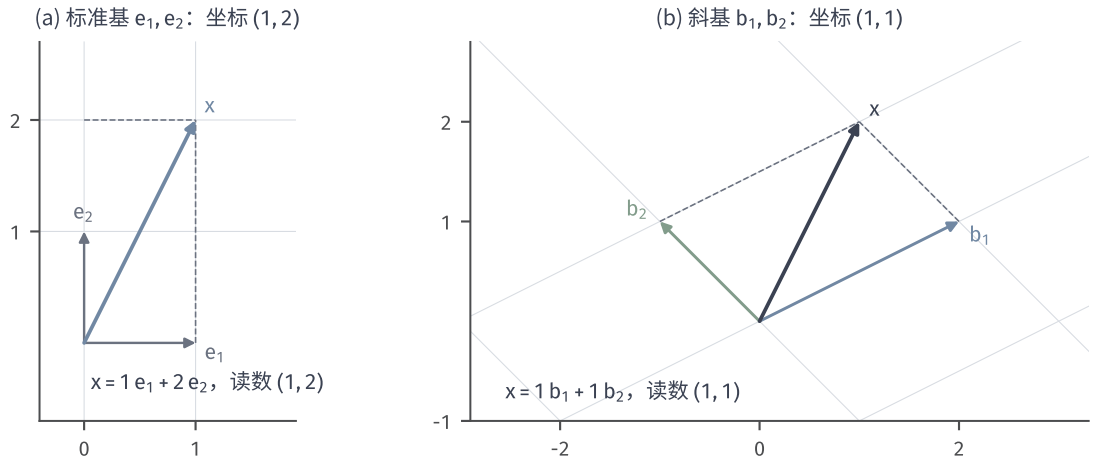


图 2.4　同一向量在两组基下的坐标。左：标准基 $\boldsymbol{e}_1, \boldsymbol{e}_2$（灰箭头）下，向量 $\boldsymbol{x} = (1,2)$（蓝箭头）的坐标为 $(1,2)$，虚线为向坐标轴的垂线。右：斜基 $\boldsymbol{b}_1 = (2,1)$（蓝）、$\boldsymbol{b}_2 = (-1,1)$（绿）下，同一个 $\boldsymbol{x}$ 满足 $\boldsymbol{x} = \boldsymbol{b}_1 + \boldsymbol{b}_2$，坐标为 $(1,1)$，浅色斜线为斜基网格，虚线为平行四边形读法。两图坐标系相同。

坐标与对象　坐标要与它记录的对象区分开。几何位移、有限信号、多项式都可以相加和缩放，它们是对象；一列实数只是选定基以后记录对象的坐标。基的顺序也要固定：交换 $\boldsymbol{b}_1, \boldsymbol{b}_2$，对象不变，坐标列的前两个数随之交换。在 $\mathbb{R}^d$ 中直接写一列数，通常默认使用标准基 $\boldsymbol{e}_1, \dots, \boldsymbol{e}_d$，这时对象与坐标恰好是同一列数。第 1章就是在这种默认下工作的。

对函数的基展开，二者必须分开：函数是对象，展开系数是坐标。

示例 2.15　仿射函数在两组基下的坐标　在 P_1 中用两组基记录同一个仿射函数 $f_{a,b} = a + bt$。在 $\mathcal{B}_1 = (1, t)$ 下，$f_{a,b} = a \cdot 1 + b \cdot t$，坐标就是截距与斜率 $(a,b)^{\mathsf{T}}$。换成 $\mathcal{B}_2 = (1, 1+t)$，设 $f_{a,b} = c_1 \cdot 1 + c_2(1+t) = (c_1 + c_2) + c_2 t$；比较 t 的系数得 $c_2 = b$，再比较常数项得 $c_1 = a - b$，即

$$f_{a,b} = (a-b) \cdot 1 + b \cdot (1+t).$$

同一个函数在 $\mathcal{B}_1$ 与 $\mathcal{B}_2$ 下的坐标分别是 $(a,b)^{\mathsf{T}}$ 与 $(a-b, b)^{\mathsf{T}}$。坐标改变了，函数本身没有改变；“截距是第一个坐标”只在 $\mathcal{B}_1$ 下成立。

坐标的个数总等于维数。若用冗余的生成组记录对象，记录的长度可以超过维数，所以不能由这种记录的长度推断空间的维数。

坐标对基的敏感性 对象不变时，不同基下的坐标仍可能相差很大。贯穿例给出一个极端的情形。

示例 2.16 近共线基下的大坐标 沿用示例 2.8中的 $\boldsymbol{c}_1, \boldsymbol{q}$ 与 $\boldsymbol{c}_2 = \boldsymbol{c}_1 + \varepsilon \boldsymbol{q}$（$\varepsilon \neq 0$），并取 $\delta = 0.1$ 与目标向量

$$\boldsymbol{y} = \boldsymbol{c}_1 + \delta \boldsymbol{q} = \begin{bmatrix} 1 \\ 1.1 \\ 0.9 \end{bmatrix}. \tag{2.5}$$

由该示例，$\mathcal{B}_0 = (\boldsymbol{c}_1, \boldsymbol{q})$ 与 $\mathcal{B}_\varepsilon = (\boldsymbol{c}_1, \boldsymbol{c}_2)$ 都是平面 $\operatorname{span}\{\boldsymbol{c}_1, \boldsymbol{q}\}$ 的基，$\boldsymbol{y}$ 也在这个平面中，所以可以比较它在两组基下的坐标。

在 $\mathcal{B}_0$ 下，$\boldsymbol{y}$ 的坐标直接读出为 $(1, \delta)^{\top}$。要换到 $\mathcal{B}_\varepsilon$，先由 $\boldsymbol{c}_2 = \boldsymbol{c}_1 + \varepsilon \boldsymbol{q}$ 解出 $\boldsymbol{q} = (\boldsymbol{c}_2 - \boldsymbol{c}_1)/\varepsilon$，再代入 $\boldsymbol{y} = \boldsymbol{c}_1 + \delta \boldsymbol{q}$，得

$$\boldsymbol{y} = \left(1 - \frac{\delta}{\varepsilon}\right) \boldsymbol{c}_1 + \frac{\delta}{\varepsilon} \boldsymbol{c}_2. \tag{2.6}$$

两个系数都含因子 δ/ε，ε 越小，坐标越大。取 $\varepsilon = 0.01$，则 $\delta/\varepsilon = 10$，坐标成为 $(-9, 10)^{\top}$。于是同一个 $\boldsymbol{y}$ 在 $\mathcal{B}_0$ 下的坐标为 $(1, 0.1)^{\top}$，在 $\mathcal{B}_{0.01}$ 下却是 $(-9, 10)^{\top}$，第二个分量从 0.1 变成了 10。

两个很大的系数作用在几乎同向的两个基向量上，大部分相互抵消，所以不能据此判断 $\boldsymbol{y}$ 很大。坐标对接近退化的基的这种敏感性，第 7章将用条件数定量讨论。要系统地比较新旧坐标，先要建立换基的一般公式。

换基矩阵 设 $\mathcal{B} = (\boldsymbol{b}_1, \dots, \boldsymbol{b}_d)$ 与 $\mathcal{C}$ 是 V 的两组有序基，已知 $\boldsymbol{v}$ 在 $\mathcal{B}$ 下的坐标 $[\boldsymbol{v}]_{\mathcal{B}} = (x_1, \dots, x_d)^{\top}$，要求它在 $\mathcal{C}$ 下的坐标。由 $\boldsymbol{v} = \sum_j x_j \boldsymbol{b}_j$，并且坐标映射保持线性组合，

$$[\boldsymbol{v}]_{\mathcal{C}} = \sum_{j=1}^{d} x_j [\boldsymbol{b}_j]_{\mathcal{C}}.$$

右边是各列 $[\boldsymbol{b}_j]_{\mathcal{C}}$ 以 x_j 为权重的线性组合。把这些列排成矩阵，称为从 $\mathcal{B}$ 到 $\mathcal{C}$ 的换基矩阵 $\boldsymbol{S}_{\mathcal{C} \leftarrow \mathcal{B}}$。按矩阵与向量乘积的列读法，

$$[\boldsymbol{v}]_{\mathcal{C}} = \boldsymbol{S}_{\mathcal{C} \leftarrow \mathcal{B}} [\boldsymbol{v}]_{\mathcal{B}}. \tag{2.7}$$

换基矩阵的第 j 列是旧基向量 $\boldsymbol{b}_j$ 的新坐标。下标 $\mathcal{C} \leftarrow \mathcal{B}$ 从右向左读，表示把 $\mathcal{B}$ 坐标换算成 $\mathcal{C}$ 坐标。下面在平面上算一个具体的换基矩阵。

示例 2.17　平面上的换基矩阵　设 $\mathbb{R}^2$ 中的向量 $\boldsymbol{v}$ 在基 $\mathcal{U}=(\boldsymbol{u}_1,\boldsymbol{u}_2)$ 下的坐标为 $(1,1)^{\mathsf{T}}$，其中 $\boldsymbol{u}_1=(1,0)^{\mathsf{T}}$、$\boldsymbol{u}_2=(1,1)^{\mathsf{T}}$，要求它在标准基 $\mathcal{E}$ 下的坐标。这里 $\mathcal{U}$ 是旧基，$\mathcal{E}$ 是新基；$\boldsymbol{u}_1,\boldsymbol{u}_2$ 的标准坐标就是它们自己，按“第 j 列是旧基向量的新坐标”排成

$$\boldsymbol{S}_{\mathcal{E}\leftarrow\mathcal{U}}=\begin{bmatrix}1 & 1\\ 0 & 1\end{bmatrix}.$$

由式 (2.7)，$[\boldsymbol{v}]_{\mathcal{E}}=\boldsymbol{S}_{\mathcal{E}\leftarrow\mathcal{U}}(1,1)^{\mathsf{T}}=(2,1)^{\mathsf{T}}$。不用换基矩阵也能得到同样结果：$\boldsymbol{v}=\boldsymbol{u}_1+\boldsymbol{u}_2=(2,1)^{\mathsf{T}}$。所以 $\mathcal{U}$ 坐标 $(1,1)^{\mathsf{T}}$ 与标准坐标 $(2,1)^{\mathsf{T}}$ 记录的是同一个向量。

图 2.5画出这一点：目标位置没有移动，改变的只是沿哪两个基方向累加，以及每个方向取多少份。

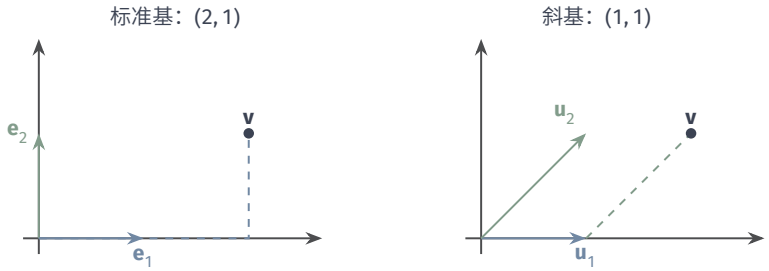


图 2.5　同一向量的两套坐标。左图使用标准基，$\boldsymbol{v}=(2,1)^{\mathsf{T}}$ 的坐标为 $(2,1)^{\mathsf{T}}$；右图使用 $\boldsymbol{u}_1=(1,0)^{\mathsf{T}}$、$\boldsymbol{u}_2=(1,1)^{\mathsf{T}}$，同一 $\boldsymbol{v}$ 的坐标为 $(1,1)^{\mathsf{T}}$。虚线表示相应的向量相加，两图的环境坐标比例相同。

连续换基与反向换基　连续换两次基，结果应与直接换基相同。设还有第三组基 $\mathcal{D}$。对每个 $\boldsymbol{v}$，连用两次式 (2.7)，

$$[\boldsymbol{v}]_{\mathcal{D}}=\boldsymbol{S}_{\mathcal{D}\leftarrow\mathcal{C}}[\boldsymbol{v}]_{\mathcal{C}}=\boldsymbol{S}_{\mathcal{D}\leftarrow\mathcal{C}}\boldsymbol{S}_{\mathcal{C}\leftarrow\mathcal{B}}[\boldsymbol{v}]_{\mathcal{B}}.$$

取 $\boldsymbol{v}=\boldsymbol{b}_j$，它的 $\mathcal{B}$ 坐标是 $\boldsymbol{e}_j$，两边读出的分别是 $\boldsymbol{S}_{\mathcal{D}\leftarrow\mathcal{B}}$ 与乘积的第 j 列，所以

$$\boldsymbol{S}_{\mathcal{D}\leftarrow\mathcal{B}}=\boldsymbol{S}_{\mathcal{D}\leftarrow\mathcal{C}}\boldsymbol{S}_{\mathcal{C}\leftarrow\mathcal{B}}.$$

特别取 $\mathcal{D}=\mathcal{B}$。每个 $\boldsymbol{b}_j$ 在 $\mathcal{B}$ 下的坐标是 $\boldsymbol{e}_j$，所以 $\boldsymbol{S}_{\mathcal{B}\leftarrow\mathcal{B}}=\boldsymbol{I}_d$，即 $\boldsymbol{S}_{\mathcal{B}\leftarrow\mathcal{C}}\boldsymbol{S}_{\mathcal{C}\leftarrow\mathcal{B}}=\boldsymbol{I}_d$；交换两组基的角色，同理得 $\boldsymbol{S}_{\mathcal{C}\leftarrow\mathcal{B}}\boldsymbol{S}_{\mathcal{B}\leftarrow\mathcal{C}}=\boldsymbol{I}_d$。所以换基矩阵总可逆，反向换基矩阵就是它的逆：

$$\boldsymbol{S}_{\mathcal{B}\leftarrow\mathcal{C}}=\boldsymbol{S}_{\mathcal{C}\leftarrow\mathcal{B}}^{-1}.$$

在示例 2.17中，

$$\boldsymbol{S}_{\mathcal{U}\leftarrow\mathcal{E}} = \boldsymbol{S}_{\mathcal{E}\leftarrow\mathcal{U}}^{-1} = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix},$$

它把 $(2,1)^{\mathsf{T}}$ 送回 $(1,1)^{\mathsf{T}}$。

反过来，任一 d 阶可逆矩阵 $\boldsymbol{P}$ 都是某次换基的矩阵。以 $\boldsymbol{P}$ 的第 j 列为 $\mathcal{B}$ 坐标，取向量 $\boldsymbol{b}'_j = \sum_i \boldsymbol{P}_{i,j}\boldsymbol{b}_i$。$\boldsymbol{P}$ 的列线性无关，而坐标映射是保持线性组合的双射，所以 $\boldsymbol{b}'_1, \dots, \boldsymbol{b}'_d$ 也线性无关。

个数等于维数的线性无关组必是基：否则它还能扩充，得到多于 $\dim V$ 个线性无关的向量，与交换引理矛盾。于是 $\boldsymbol{b}'_1, \dots, \boldsymbol{b}'_d$ 构成一组基 $\mathcal{B}'$。按定义，$\boldsymbol{S}_{\mathcal{B}\leftarrow\mathcal{B}'}$ 的第 j 列是 $\boldsymbol{b}'_j$ 的 $\mathcal{B}$ 坐标，即 $\boldsymbol{P}$ 的第 j 列，所以 $\boldsymbol{S}_{\mathcal{B}\leftarrow\mathcal{B}'} = \boldsymbol{P}$。

换基矩阵接近不可逆时，反向换基会放大坐标。贯穿例清楚地显示了这一点。

示例 2.18　近共线基之间的换基　回到示例 2.16中的两组基 $\mathcal{B}_0 = (\boldsymbol{c}_1, \boldsymbol{q})$ 与 $\mathcal{B}_\varepsilon = (\boldsymbol{c}_1, \boldsymbol{c}_2)$，$\varepsilon \neq 0$，用换基矩阵重做那里的坐标换算。由 $\boldsymbol{c}_1 = 1\cdot\boldsymbol{c}_1 + 0\cdot\boldsymbol{q}$ 与 $\boldsymbol{c}_2 = 1\cdot\boldsymbol{c}_1 + \varepsilon\boldsymbol{q}$，$\mathcal{B}_\varepsilon$ 的两个向量在 $\mathcal{B}_0$ 下的坐标分别是 $(1,0)^{\mathsf{T}}$ 与 $(1,\varepsilon)^{\mathsf{T}}$。以它们为列得到 $\boldsymbol{S}_{\mathcal{B}_0\leftarrow\mathcal{B}_\varepsilon}$，求逆得到反方向的换基矩阵：

$$\boldsymbol{S}_{\mathcal{B}_0\leftarrow\mathcal{B}_\varepsilon} = \begin{bmatrix} 1 & 1 \\ 0 & \varepsilon \end{bmatrix}$$

$$\boldsymbol{S}_{\mathcal{B}_\varepsilon\leftarrow\mathcal{B}_0} = \boldsymbol{S}_{\mathcal{B}_0\leftarrow\mathcal{B}_\varepsilon}^{-1} = \begin{bmatrix} 1 & -1/\varepsilon \\ 0 & 1/\varepsilon \end{bmatrix},$$

逆矩阵可由两者相乘得单位矩阵验证。把 $\boldsymbol{y}$ 在 $\mathcal{B}_0$ 下的坐标 $(1,\delta)^{\mathsf{T}}$ 代入后者，得

$$\boldsymbol{S}_{\mathcal{B}_\varepsilon\leftarrow\mathcal{B}_0}\begin{bmatrix} 1 \\ \delta \end{bmatrix} = \begin{bmatrix} 1-\delta/\varepsilon \\ \delta/\varepsilon \end{bmatrix},$$

与式 (2.6)一致。

放大的来源在矩阵上看得很清楚。$\boldsymbol{S}_{\mathcal{B}_0\leftarrow\mathcal{B}_\varepsilon}$ 的行列式为 ε，接近零，矩阵接近不可逆；它的逆因而含有因子 $1/\varepsilon$，两组基之间的微小差异由此被放大成大系数。

被动换基与主动作用　换基公式与矩阵作用都写成矩阵乘以坐标列，但含义不同，必须分开。换基是被动的：对象不动，记录改变，式(2.7)两侧是同一个 $\boldsymbol{v}$ 的两套坐标。矩阵作用是主动的：坐标系不动，对象被送到另一个对象，例如第 1章的 $\boldsymbol{x} \mapsto \boldsymbol{A}\boldsymbol{x}$ 把向量旋转或切变；下一节把这种作用推广为线性映射。下面的例子从同一个初始向量出发比较两种情形。

示例 2.19　被动换基与主动切变　取 $\mathbb{R}^2$ 中的向量 $\boldsymbol{x}=(3,3)^{\mathsf{T}}$，分别对它作被动换基与主动切变。换基用斜基 $\mathcal{B}'=(\boldsymbol{b}_1,\boldsymbol{b}_2)$，$\boldsymbol{b}_1=(2,1)^{\mathsf{T}}$、$\boldsymbol{b}_2=(-1,1)^{\mathsf{T}}$；切变用矩阵

$$\boldsymbol{A}=\begin{bmatrix}1 & 1\\ 0 & 1\end{bmatrix}.$$

被动换基要求 $\boldsymbol{x}$ 在 $\mathcal{B}'$ 下的坐标 $(c_1,c_2)^{\mathsf{T}}$。由 $2c_1-c_2=3$ 与 $c_1+c_2=3$ 得 $c_1=2$、$c_2=1$，即 $\boldsymbol{x}=2\boldsymbol{b}_1+\boldsymbol{b}_2$。这时向量仍是 $(3,3)^{\mathsf{T}}$，只是读数从 $(3,3)$ 变成 $(2,1)$。主动作用则在标准坐标下计算 $\boldsymbol{A}\boldsymbol{x}=(3+3,\,3)^{\mathsf{T}}=(6,3)^{\mathsf{T}}$：坐标系不动，向量本身被搬到了另一个位置。

图 2.6把两种情形并排画出。可见，并非所有乘矩阵的运算都是换基。

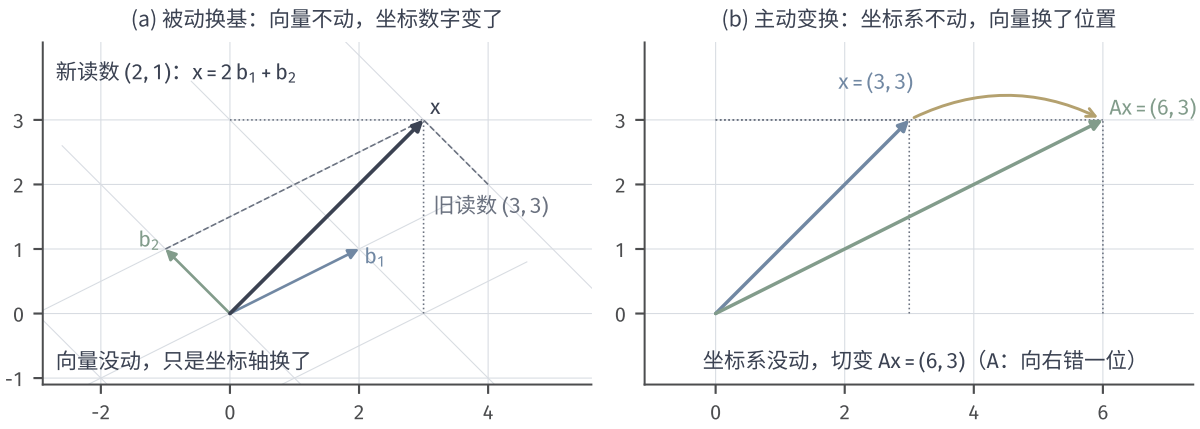


图 2.6　被动换基与主动变换的对照，两图使用同一个初始向量 $\boldsymbol{x}=(3,3)$。左（被动换基）：箭头位置不动（深色），旧标准读数用点线投影读出 $(3,3)$；新斜基 $\boldsymbol{b}_1=(2,1)$（蓝）、$\boldsymbol{b}_2=(-1,1)$（绿）与浅色斜网格下，$\boldsymbol{x}=2\boldsymbol{b}_1+\boldsymbol{b}_2$，新读数为 $(2,1)$。右（主动变换）：标准坐标系不动，$\boldsymbol{x}$（蓝）被切变映到 $\boldsymbol{A}\boldsymbol{x}=(6,3)$（绿），黄色弧线表示搬动过程。

2.3　线性与多线性映射

前两节讨论单个空间中的对象怎样记录。本节转向对象之间保持线性组合的作用，即线性映射。选定两端的基，线性映射记成矩阵，映射的叠加、复合与求逆对应矩阵的加法、乘法与求逆。核与像分别描述映射消去的输入和能到达的输出，秩零度定理联系二者的维数，并由此给出可逆的判据。换基改变矩阵而不改变映射：两端各自换基得到相抵，算子两端同时换基得到相似。最后简述对每个输入分别线性的多线性映射。

2.3.1 线性映射及其矩阵表示

设计矩阵把一组系数变成一列拟合值，求导把一个多项式变成另一个多项式，读取第一个坐标把向量变成一个数。这些作用有一个共同点：先把输入加权相加再作用，与先分别作用再作同样的加权相加，结果相同。有了这一性质，输入写成基向量的组合以后，作用的结果就是各基向量的像的同样组合，前两节的语言可以直接用于作用本身。保持线性组合的作用称为**线性映射**（linear map）$T : V \to W$：

$$T(a\boldsymbol{x} + b\boldsymbol{y}) = aT\boldsymbol{x} + bT\boldsymbol{y}, \qquad \boldsymbol{x}, \boldsymbol{y} \in V,\ a, b \in \mathbb{R}. \tag{2.8}$$

取 $a = b = 0$ 得 $T\mathbf{0} = \mathbf{0}$，线性映射总把零向量送到零向量。由式 (1.6)，任何矩阵 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$ 给出的 $\boldsymbol{x} \mapsto \boldsymbol{A}\boldsymbol{x}$ 都是从 $\mathbb{R}^d$ 到 $\mathbb{R}^m$ 的线性映射。下面再检查几个作用是否线性。

示例 2.20　线性与非线性的作用　考察下面三个作用：

$$\begin{aligned} &T : \mathbb{R}^2 \to \mathbb{R}^2, \quad T(x_1, x_2) = (2x_1 + x_2,\ 3x_2); \\ &D : P_k \to P_k, \quad Dp = p'; \\ &\tau : \mathbb{R} \to \mathbb{R}, \qquad \tau(x) = x + 1. \end{aligned}$$

T 的两个输出分量都是输入的加权和，写成矩阵就是

$$T\boldsymbol{x} = \begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix} \boldsymbol{x},$$

所以它是矩阵给出的映射，保持线性组合。求导满足 $(ap + bq)' = ap' + bq'$，所以 D 也保持线性组合；又因为求导不升高次数，D 确实把 P_k 送回 P_k。

τ 看起来同样简单，却不是线性映射：$\tau(0) = 1 \neq 0$，而线性映射必把 0 送到 0。加上常数就把零点移走了，这与示例 2.3中平移后的直线不含零向量是同一类现象。

输入与输出是同一个空间的线性映射 $T : V \to V$ 称为**线性算子**（linear operator），也称线性变换。平面上的旋转、向一条直线的投影、P_k 上的求导都是线性算子，示例 2.20中的 T 也是。

输入与输出相同，使算子与一般映射有两点不同。第一，算子的输出仍在 V 中，可以再次作为输入，所以算子能与自身复合、反复作用。记 $T^2 = T\circ T$、$T^k = T\circ T^{k-1}$，并约定 $T^0 = \mathrm{id}_V$。一般映射 $V \to W$ 在 $V \neq W$ 时不能这样反复作用。后面将看到，在同一组基下，T^k 的矩阵就是 T 的

矩阵的 k 次幂。第二，记录算子时，输入和输出可以用同一组基，这决定了算子换基时的特殊规律（第 2.3.4.2节）。

线性映射的定义域通常有无穷多个元素，不可能逐个记录输出。选定基以后，有限个数就够了：在两端的固定基下，线性映射与矩阵一一对应，映射的叠加、复合与求逆分别对应矩阵的加法、乘法与求逆。第 1章的矩阵由此获得一般含义：矩阵是线性映射在坐标下的记录。下面先建立这一对应，再翻译映射的运算，最后定义矩阵的四个基本子空间，供下一小节使用。

2.3.1.1 矩阵表示

给定输入基 $\mathcal{B}=(\boldsymbol{b}_1,\dots,\boldsymbol{b}_d)$，任一 $\boldsymbol{v}=\sum_j x_j\boldsymbol{b}_j$ 的像由线性性写成

$$T\boldsymbol{v}=\sum_{j=1}^{d} x_j\,T\boldsymbol{b}_j,$$

所以只要知道 d 个基向量的像，整个映射就确定了。再给定输出基 $\mathcal{C}$，把每个像的坐标 $[T\boldsymbol{b}_j]_{\mathcal{C}}$ 作为第 j 列，排成矩阵 $\boldsymbol{A}=[T]_{\mathcal{C}\leftarrow\mathcal{B}}\in\mathbb{R}^{m\times d}$，称为 T 在这两组基下的矩阵。

对上式两边取 $\mathcal{C}$ 坐标，由坐标映射保持线性组合，并按矩阵与向量乘积的列读法，得到

$$[T\boldsymbol{v}]_{\mathcal{C}}=\sum_{j=1}^{d} x_j\,[T\boldsymbol{b}_j]_{\mathcal{C}}=\sum_{j=1}^{d} x_j\boldsymbol{A}_{:,j}=[T]_{\mathcal{C}\leftarrow\mathcal{B}}\,[\boldsymbol{v}]_{\mathcal{B}}. \tag{2.9}$$

也就是说，输出坐标等于矩阵乘以输入坐标。作用在对象上进行，记录在坐标上进行，二者由矩阵与向量的乘积连接。

矩阵的列数是输入维数，行数是输出维数。下标 $\mathcal{C}\leftarrow\mathcal{B}$ 从右向左读，表示输入用 $\mathcal{B}$ 记录、输出用 $\mathcal{C}$ 记录。算子的两端通常用同一组基，记为 $[T]_{\mathcal{B}}=[T]_{\mathcal{B}\leftarrow\mathcal{B}}$，它是 $\dim V$ 阶方阵。

下面按这一规则写出两个映射的矩阵。

示例 2.21　由基向量的像写出矩阵　对示例 2.20中的 $T(x_1,x_2)=(2x_1+x_2,\,3x_2)$，输入输出都取标准基。两个基向量的像是 $T\boldsymbol{e}_1=(2,0)^{\top}$ 与 $T\boldsymbol{e}_2=(1,3)^{\top}$，它们在标准基下的坐标就是自身。依次作为两列，得

$$[T]=\begin{bmatrix}2 & 1\\ 0 & 3\end{bmatrix}.$$

这正是定义 T 时用的矩阵：按规则从基向量的像重建矩阵，没有丢失任何信息。

一般地，$\boldsymbol{x} \mapsto \boldsymbol{A}\boldsymbol{x}$ 在标准基下的矩阵就是 $\boldsymbol{A}$ 本身，因为 $\boldsymbol{A}\boldsymbol{e}_j = \boldsymbol{A}_{:,j}$。矩阵表示同样适用于不是数组的对象。

示例 2.22　求导的矩阵表示　考虑求导 $D : P_2 \to P_2$，输入输出都取基 $(1, t, t^2)$。三个基向量的导数是 $D1 = 0$、$Dt = 1$、$Dt^2 = 2t$，它们在这组基下的坐标依次为 $(0,0,0)^{\top}$、$(1,0,0)^{\top}$、$(0,2,0)^{\top}$。以此为列，

$$[D] = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 2 \\ 0 & 0 & 0 \end{bmatrix}.$$

用一般的多项式检验这个矩阵。$p = a_0 + a_1 t + a_2 t^2$ 的坐标是 $(a_0, a_1, a_2)^{\top}$，而 $[D](a_0, a_1, a_2)^{\top} = (a_1, 2a_2, 0)^{\top}$，正是 $p' = a_1 + 2a_2 t$ 的坐标。对多项式求导，在坐标下就是乘矩阵 $[D]$，尽管多项式本身不是一列数。

两个例子都是先有映射、再写矩阵。反过来，每个同形矩阵也都记录某个线性映射。

定理 2.23　线性映射与矩阵的对应　设 $\dim V = d$、$\dim W = m$，并固定 V 的基 $\mathcal{B}$ 与 W 的基 $\mathcal{C}$。则 $T \mapsto [T]_{\mathcal{C}\leftarrow\mathcal{B}}$ 是从全部线性映射 $V \to W$ 到全部 $m \times d$ 实矩阵的双射。

证明　单射：若两个线性映射的矩阵相同，它们在每个基向量上的像相同，由 $T\boldsymbol{v} = \sum_j x_j T\boldsymbol{b}_j$，它们在每个 $\boldsymbol{v}$ 上都相同。满射：任给 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$，对 $\boldsymbol{v} \in V$ 令 $T\boldsymbol{v}$ 为 $\mathcal{C}$ 坐标等于 $\boldsymbol{A}[\boldsymbol{v}]_{\mathcal{B}}$ 的那个向量。坐标唯一，所以这一规则有确定的意义；坐标映射与乘矩阵都保持线性组合，所以 T 线性；$T\boldsymbol{b}_j$ 的坐标是 $\boldsymbol{A}\boldsymbol{e}_j = \boldsymbol{A}_{:,j}$，所以 $[T]_{\mathcal{C}\leftarrow\mathcal{B}} = \boldsymbol{A}$。 ■

所以基固定以后，线性映射与矩阵一一对应；特别地，每个从 $\mathbb{R}^d$ 到 $\mathbb{R}^m$ 的线性映射在标准基下都是乘某个矩阵。这一对应依赖基的选取：改变两端任一组基，数表通常随之改变，记录的仍是同一个映射。数表怎样随基改变，在第 2.3.4节推导。

设计矩阵 $\boldsymbol{X}_{\varepsilon}$ 就是这样一张记录。它表示 $T_{\varepsilon} : \mathbb{R}^2 \to \mathbb{R}^3$，$\boldsymbol{w} \mapsto \boldsymbol{X}_{\varepsilon}\boldsymbol{w} = w_1\boldsymbol{c}_1 + w_2\boldsymbol{c}_2$，两列分别是两个输入基向量的像。输入是两个系数，输出是三个样本的拟合值，二者不在同一个空间中。图 2.7概括了对象与坐标的关系：先作用于对象再取坐标，与先取输入坐标再乘矩阵，得到相同的输出坐标。

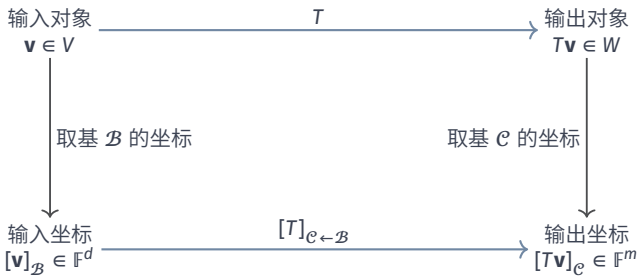


图 2.7　先作用于对象再取坐标，与先取输入坐标再按矩阵的列作线性组合（即乘矩阵），得到相同输出坐标。横向箭头改变对象或数值，竖向箭头只改变记录方式。

2.3.1.2 基于矩阵的映射运算

映射之间有几种常用运算：把两个映射的输出相加，让两个映射接连作用，撤销一个映射。在固定基下，它们分别记录为第 1章的矩阵加法、乘法与求逆。带常数偏置的仿射映射不是线性映射，但可以借增广坐标写成一张更大的矩阵。

叠加　设 $T, S : V \to W$ 是同一对空间之间的两个线性映射，定义

$$(aT + bS)(\boldsymbol{x}) = aT\boldsymbol{x} + bS\boldsymbol{x}, \qquad \boldsymbol{x} \in V,\ a, b \in \mathbb{R}.$$

把输入的线性组合代入，两项分别展开再汇总，可知叠加仍是线性映射。在 V 与 W 的固定基下，设 T, S 的矩阵为 $\boldsymbol{A}, \boldsymbol{B}$。$aT + bS$ 把第 j 个基向量送到 $aT\boldsymbol{b}_j + bS\boldsymbol{b}_j$，其坐标是 $a\boldsymbol{A}_{:,j} + b\boldsymbol{B}_{:,j}$，所以 $aT + bS$ 的矩阵就是 $a\boldsymbol{A} + b\boldsymbol{B}$。

相加要求两个映射的定义域相同、陪域也相同，这对应于只有同形矩阵才能相加。它不要求 $V = W$：两个从 $\mathbb{R}^2$ 到 $\mathbb{R}^3$ 的映射可以相加，但不能与一个从 $\mathbb{R}^3$ 到 $\mathbb{R}^2$ 的映射相加。系数 a, b 必须与输入无关；若系数随 $\boldsymbol{x}$ 改变，叠加的结果一般不再线性，需要单独检验。

复合　设 $T : U \to V$、$S : V \to W$ 是线性映射。复合 $S \circ T$ 先作用 T、再作用 S，仍保持线性组合：

$$S(T(a\boldsymbol{x} + b\boldsymbol{y})) = S(aT\boldsymbol{x} + bT\boldsymbol{y}) = aS(T\boldsymbol{x}) + bS(T\boldsymbol{y}).$$

取 U,V,W 的基 $\mathcal{B},\mathcal{C},\mathcal{D}$。对每个 $\boldsymbol{x}\in U$，两次使用式 (2.9)，再用矩阵乘法的结合律，得

$$[S(T\boldsymbol{x})]_{\mathcal{D}}=[S]_{\mathcal{D}\leftarrow\mathcal{C}}[T\boldsymbol{x}]_{\mathcal{C}}=[S]_{\mathcal{D}\leftarrow\mathcal{C}}\big([T]_{\mathcal{C}\leftarrow\mathcal{B}}[\boldsymbol{x}]_{\mathcal{B}}\big)=\big([S]_{\mathcal{D}\leftarrow\mathcal{C}}[T]_{\mathcal{C}\leftarrow\mathcal{B}}\big)[\boldsymbol{x}]_{\mathcal{B}}.$$

取 $\boldsymbol{x}=\boldsymbol{b}_j$，其坐标是 $\boldsymbol{e}_j$，两边读出的是 $[S\circ T]_{\mathcal{D}\leftarrow\mathcal{B}}$ 与乘积的第 j 列，所以

$$[S\circ T]_{\mathcal{D}\leftarrow\mathcal{B}}=[S]_{\mathcal{D}\leftarrow\mathcal{C}}\,[T]_{\mathcal{C}\leftarrow\mathcal{B}}. \tag{2.10}$$

复合的矩阵是矩阵的乘积，中间空间 V 的基 $\mathcal{C}$ 在乘积中消去；第 1.2.5节的推导是这里取标准基的特例。恒等映射 id_V 在同一组基下的矩阵是单位矩阵。映射复合的结合律对应矩阵乘法的结合律；矩阵乘法不可交换，对应先后作用的次序不能交换。

对算子 $T:V\to V$ 两端都用基 $\mathcal{B}$，反复使用式 (2.10)，得 $[T^k]_{\mathcal{B}}=([T]_{\mathcal{B}})^k$。算子的反复作用因此记录为第 1.2.9节的矩阵幂。例如对示例 2.22中的 $[D]$ 直接相乘可得 $[D]^3=\boldsymbol{0}$，这对应于任何次数不超过 2 的多项式求导三次都变为零。

逆映射　第 1.2.8节把满足 $\boldsymbol{AB}=\boldsymbol{BA}=\boldsymbol{I}$ 的方阵 $\boldsymbol{A}$ 称为可逆矩阵，那里只把它看成可以撤销的数表运算。有了矩阵表示，可以说明它记录的是哪一类映射。

若线性映射 $T:V\to W$ 是双射，每个输出恰有一个原输入，逆映射 $T^{-1}:W\to V$ 存在。逆映射自动是线性的：对 $\boldsymbol{w},\boldsymbol{w}'\in W$，由 T 的线性性

$$T\big(aT^{-1}\boldsymbol{w}+bT^{-1}\boldsymbol{w}'\big)=a\boldsymbol{w}+b\boldsymbol{w}',$$

所以 $aT^{-1}\boldsymbol{w}+bT^{-1}\boldsymbol{w}'$ 就是 $a\boldsymbol{w}+b\boldsymbol{w}'$ 唯一的原输入，即 $T^{-1}(a\boldsymbol{w}+b\boldsymbol{w}')=aT^{-1}\boldsymbol{w}+bT^{-1}\boldsymbol{w}'$。这样的 T 称为可逆线性映射。

可逆映射与可逆矩阵相互对应。设 $T:V\to W$ 可逆，在基 $\mathcal{B},\mathcal{C}$ 下 $\boldsymbol{A}=[T]_{\mathcal{C}\leftarrow\mathcal{B}}$，$\boldsymbol{B}=[T^{-1}]_{\mathcal{B}\leftarrow\mathcal{C}}$。由式 (2.10)，$T^{-1}\circ T=\mathrm{id}_V$ 与 $T\circ T^{-1}=\mathrm{id}_W$ 分别给出 $\boldsymbol{BA}=\boldsymbol{I}$ 与 $\boldsymbol{AB}=\boldsymbol{I}$。所以 $\boldsymbol{A}$ 是可逆方阵（下一小节将说明此时必有 $\dim V=\dim W$），且 $[T^{-1}]_{\mathcal{B}\leftarrow\mathcal{C}}=\boldsymbol{A}^{-1}$。反过来，若 $\boldsymbol{A}$ 可逆，$\boldsymbol{y}\mapsto\boldsymbol{A}^{-1}\boldsymbol{y}$ 就是 $\boldsymbol{x}\mapsto\boldsymbol{Ax}$ 的逆映射。

两个可逆映射接连作用时，$(S\circ T)^{-1}=T^{-1}\circ S^{-1}$，在矩阵上就是式 (1.9)。判断一个映射是否可逆，要先知道它丢失了什么、能到达什么，这由下一小节处理。

仿射映射　线性模型的预测常带截距，平面上的平移也常与旋转一起出现，这些作用都不把原点留在原处。带常数偏置的规则 $\boldsymbol{x}\mapsto\boldsymbol{Ax}+\boldsymbol{b}$ 称为**仿射**

映射（affine map）。当 $\boldsymbol{b} \neq \boldsymbol{0}$ 时，它把 $\boldsymbol{0}$ 送到 $\boldsymbol{b}$，所以不是线性映射；当 $\boldsymbol{b} = \boldsymbol{0}$ 时，它就是线性映射。

两个仿射映射 $\boldsymbol{x} \mapsto \boldsymbol{A}_1\boldsymbol{x} + \boldsymbol{b}_1$、$\boldsymbol{y} \mapsto \boldsymbol{A}_2\boldsymbol{y} + \boldsymbol{b}_2$ 复合，得到

$$\boldsymbol{x} \mapsto \boldsymbol{A}_2\boldsymbol{A}_1\boldsymbol{x} + (\boldsymbol{A}_2\boldsymbol{b}_1 + \boldsymbol{b}_2),$$

前一个映射的平移项也受到后一个映射的作用。

给坐标补一个恒为 1 的末位，仿射映射就能写成高一维空间上的线性作用：

$$\begin{bmatrix} \boldsymbol{A} & \boldsymbol{b} \\ \boldsymbol{0}^\top & 1 \end{bmatrix} \begin{bmatrix} \boldsymbol{x} \\ 1 \end{bmatrix} = \begin{bmatrix} \boldsymbol{A}\boldsymbol{x} + \boldsymbol{b} \\ 1 \end{bmatrix}. \tag{2.11}$$

按分块乘法，两个这样的增广矩阵相乘得

$$\begin{bmatrix} \boldsymbol{A}_2 & \boldsymbol{b}_2 \\ \boldsymbol{0}^\top & 1 \end{bmatrix} \begin{bmatrix} \boldsymbol{A}_1 & \boldsymbol{b}_1 \\ \boldsymbol{0}^\top & 1 \end{bmatrix} = \begin{bmatrix} \boldsymbol{A}_2\boldsymbol{A}_1 & \boldsymbol{A}_2\boldsymbol{b}_1 + \boldsymbol{b}_2 \\ \boldsymbol{0}^\top & 1 \end{bmatrix},$$

正是复合仿射映射的增广矩阵。

增广矩阵在整个增广空间上是线性的，但原输入只取末坐标为 1 的向量，所以不能据此说原映射线性。第 9章用这种形式描述仿射解集的几何。

2.3.1.3 矩阵基本子空间

矩阵 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$ 给出从 $\mathbb{R}^d$ 到 $\mathbb{R}^m$ 的映射 $\boldsymbol{x} \mapsto \boldsymbol{A}\boldsymbol{x}$，它的转置 $\boldsymbol{A}^\top \in \mathbb{R}^{d\times m}$ 给出反方向的映射 $\boldsymbol{y} \mapsto \boldsymbol{A}^\top\boldsymbol{y}$。对每个方向可以问两个问题：哪些输出能够到达，哪些输入被送到零。四个答案都是子空间，它们刻画了矩阵保留和丢失的信息。

按矩阵与向量乘积的列读法，$\boldsymbol{A}\boldsymbol{x} = \sum_j x_j \boldsymbol{A}_{:,j}$。$\boldsymbol{x}$ 取遍 $\mathbb{R}^d$ 时，输出取遍 $\boldsymbol{A}$ 各列的全部线性组合，即各列的张成空间，称为 $\boldsymbol{A}$ 的**列空间**（column space），记为 range($\boldsymbol{A}$)。所以方程 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 有解，当且仅当 $\boldsymbol{b} \in$ range($\boldsymbol{A}$)。

齐次方程组 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{0}$ 的解集合是 $\mathbb{R}^d$ 的子空间（示例 2.3），称为 $\boldsymbol{A}$ 的**零空间**（null space），记为 null($\boldsymbol{A}$)。

对 $\boldsymbol{A}^\top$ 问同样的两个问题，又得到两个子空间。$\boldsymbol{A}^\top$ 的列就是 $\boldsymbol{A}$ 的行，所以 range($\boldsymbol{A}^\top$) 由 $\boldsymbol{A}$ 各行的线性组合组成，称为 $\boldsymbol{A}$ 的**行空间**（row space）。$\boldsymbol{A}^\top\boldsymbol{y} = \boldsymbol{0}$ 转置后就是 $\boldsymbol{y}^\top\boldsymbol{A} = \boldsymbol{0}^\top$，即 $\boldsymbol{y}^\top$ 从左边乘 $\boldsymbol{A}$ 得到零，所以 null($\boldsymbol{A}^\top$)

称为 $\boldsymbol{A}$ 的**左零空间**（left null space）。这四个子空间合称 $\boldsymbol{A}$ 的**四个基本子空间**（four fundamental subspaces）：

$$\begin{aligned} \operatorname{range}(\boldsymbol{A}) &= \{\boldsymbol{A}\boldsymbol{x} : \boldsymbol{x} \in \mathbb{R}^d\} \subseteq \mathbb{R}^m, \\ \operatorname{null}(\boldsymbol{A}) &= \{\boldsymbol{x} \in \mathbb{R}^d : \boldsymbol{A}\boldsymbol{x} = \boldsymbol{0}\} \subseteq \mathbb{R}^d, \\ \operatorname{range}(\boldsymbol{A}^\top) &= \{\boldsymbol{A}^\top \boldsymbol{y} : \boldsymbol{y} \in \mathbb{R}^m\} \subseteq \mathbb{R}^d, \\ \operatorname{null}(\boldsymbol{A}^\top) &= \{\boldsymbol{y} \in \mathbb{R}^m : \boldsymbol{A}^\top \boldsymbol{y} = \boldsymbol{0}\} \subseteq \mathbb{R}^m. \end{aligned} \tag{2.12}$$

零空间与行空间在输入空间 $\mathbb{R}^d$ 中，列空间与左零空间在输出空间 $\mathbb{R}^m$ 中。零空间收集被完全消去的输入方向。行空间收集读取输出分量所用的方向：输出的第 i 个分量 $(\boldsymbol{A}\boldsymbol{x})_i = \boldsymbol{A}_{i,:}\boldsymbol{x}$ 由第 i 行与 $\boldsymbol{x}$ 逐项相乘再相加得到。左零空间收集对可达输出读数恒为零的加权方式：对 $\boldsymbol{y} \in \operatorname{null}(\boldsymbol{A}^\top)$ 与任意输入 $\boldsymbol{x}$，$\boldsymbol{y}^\top(\boldsymbol{A}\boldsymbol{x}) = (\boldsymbol{y}^\top\boldsymbol{A})\boldsymbol{x} = 0$。

下面对一个具体矩阵求出四个基本子空间。

示例 2.24　一个 2×3 矩阵的四个基本子空间　取

$$\boldsymbol{A} = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \end{bmatrix} \in \mathbb{R}^{2\times 3}.$$

它的第二行是第一行的 2 倍，每一列也都是 $(1,2)^\top$ 的倍数，四个子空间都可以直接读出。

先看输出空间 $\mathbb{R}^2$。三列 $(1,2)^\top$、$(2,4)^\top$、$(3,6)^\top$ 都落在同一条直线上，所以列空间 $\operatorname{range}(\boldsymbol{A}) = \operatorname{span}\{(1,2)^\top\}$。左零空间要求 $\boldsymbol{y}^\top\boldsymbol{A} = (y_1+2y_2)(1,2,3)$ 为零，即 $y_1 = -2y_2$，所以 $\operatorname{null}(\boldsymbol{A}^\top) = \operatorname{span}\{(2,-1)^\top\}$，也是一条直线。

再看输入空间 $\mathbb{R}^3$。两行都是 $(1,2,3)$ 的倍数，所以行空间 $\operatorname{range}(\boldsymbol{A}^\top) = \operatorname{span}\{(1,2,3)^\top\}$ 是一条直线。因为第二行重复第一行，$\boldsymbol{A}\boldsymbol{x} = \boldsymbol{0}$ 只剩一个方程 $x_1 + 2x_2 + 3x_3 = 0$，由示例 2.10，零空间 $\operatorname{null}(\boldsymbol{A}) = \operatorname{span}\{(-2,1,0)^\top, (-3,0,1)^\top\}$ 是一个平面。

四个维数依次为：列空间 1、零空间 2、行空间 1、左零空间 1。其中有两条规律。一是列空间与行空间维数相同。二是同一端的两个子空间维数互补：输入空间中零空间与行空间的维数之和为 $2+1=3$，输出空间中列空间与左零空间的维数之和为 $1+1=2$。此外，行空间的方向 $(1,2,3)^\top$ 与零空间的两个基向量逐项相乘再相加都得零（$-2+2+0=0$，$-3+0+3=0$），列空间的方向 $(1,2)^\top$ 与左零空间的方向 $(2,-1)^\top$ 也是如此（$2-2=0$）。

第 2.3.2节将证明，示例中的两条维数规律对任何矩阵都成立；垂直关系要等第 3.5.1节有了内积才能说清。

2.3.2 核、像与秩

能否由输出反求输入，取决于映射丢失了哪些输入信息、能产生哪些输出。本小节把这两方面写成核与像两个子空间，用秩零度定理联系二者的维数，再从商空间的角度重新解释这一关系，最后算出矩阵四个基本子空间的维数。

核与像　被映射送到零的输入集合称为 T 的核（kernel），记为

$$\ker T = \{\boldsymbol{x} \in V : T\boldsymbol{x} = \boldsymbol{0}\};$$

所有可到达的输出组成的集合称为**像空间**（简称像，image），记为

$$\operatorname{im} T = \{T\boldsymbol{x} : \boldsymbol{x} \in V\}.$$

二者都是子空间：若 $T\boldsymbol{x} = T\boldsymbol{y} = \boldsymbol{0}$，则 $T(a\boldsymbol{x}+b\boldsymbol{y}) = \boldsymbol{0}$；若 $\boldsymbol{u} = T\boldsymbol{x}$、$\boldsymbol{v} = T\boldsymbol{y}$，则 $a\boldsymbol{u} + b\boldsymbol{v} = T(a\boldsymbol{x} + b\boldsymbol{y})$。

核位于输入端，像位于输出端，二者不在同一空间中，不能直接比较。对矩阵 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$，映射 $\boldsymbol{x} \mapsto \boldsymbol{A}\boldsymbol{x}$ 的核就是零空间 $\operatorname{null}(\boldsymbol{A})$，像就是列空间 $\operatorname{range}(\boldsymbol{A})$（第 2.3.1.3节）。说“矩阵 $\boldsymbol{A}$ 的核”“矩阵 $\boldsymbol{A}$ 的秩”时，指的都是映射 $\boldsymbol{x} \mapsto \boldsymbol{A}\boldsymbol{x}$ 的相应量。

核代表丢失的信息，理由如下：$T\boldsymbol{x} = T\boldsymbol{y}$ 当且仅当 $T(\boldsymbol{x} - \boldsymbol{y}) = \boldsymbol{0}$，即 $\boldsymbol{x} - \boldsymbol{y} \in \ker T$。所以两个输入相差一个核中的向量时，输出完全相同。下面的例子用三个响应读取四个分量，展示这一点。

示例 2.25　相差核方向的输入给出相同输出　设 $T : \mathbb{R}^4 \to \mathbb{R}^3$ 把第四个分量分别加到前三个分量上：

$$T(x_1, x_2, x_3, x_4) = (x_1 + x_4,\ x_2 + x_4,\ x_3 + x_4).$$

三个响应全为零，要求 $x_1 = x_2 = x_3 = -x_4$，所以 $\ker T = \operatorname{span}\{(1,1,1,-1)^{\mathsf{T}}\}$。另一方面，取 $x_4 = 0$ 时 $T\boldsymbol{x} = (x_1, x_2, x_3)$ 可以是任意向量，所以 $\operatorname{im} T = \mathbb{R}^3$：每个输出都能到达，但核不为零。

具体比较两个输入 $(1,1,1,1)^{\mathsf{T}}$ 与 $(0,0,0,2)^{\mathsf{T}}$。它们之差 $(1,1,1,-1)^{\mathsf{T}}$ 恰在核中，于是

$$T(1,1,1,1) = T(0,0,0,2) = (2,2,2).$$

仅凭三个响应无法区分这两个输入；同样的论证说明，任何两个相差 $(1,1,1,-1)^{\top}$ 倍数的输入都无法区分。

这就是线性不可辨识性：两个输入相差核方向时输出相同，只凭输出无法确定输入。若另有约束限制了可取的输入，能否辨识还要结合这些约束判断。

秩零度定理 核与像的维数之间有一个精确的关系。像的维数称为**秩**（rank），记为 $\operatorname{rank} T = \dim \operatorname{im} T$；核的维数称为**零度**（nullity），即 $\dim \ker T$。

定理 2.26 秩零度定理 有限维线性映射 $T : V \to W$ 满足

$$\begin{aligned} \dim V &= \dim \ker T + \dim \operatorname{im} T \\ \text{即} \qquad \dim V &= \dim \ker T + \operatorname{rank} T. \end{aligned} \tag{2.13}$$

证明 取核的一组基 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_r$，扩充成 V 的基 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_d$。前 r 个基向量的像为零，所以其余的像 $T\boldsymbol{v}_{r+1}, \dots, T\boldsymbol{v}_d$ 张成像。若 $\sum_{j>r} a_j T\boldsymbol{v}_j = \boldsymbol{0}$，则 $\sum_{j>r} a_j \boldsymbol{v}_j$ 属于核，能由前 r 个基向量表示；整组基的线性无关性迫使全部 $a_j = 0$，所以这些像线性无关。于是像的维数为 $d - r$，结论成立。 ■

对矩阵 $\boldsymbol{A} \in \mathbb{R}^{m \times d}$，记 $\operatorname{rank} \boldsymbol{A}$ 为其映射的秩，即列空间的维数，则

$$d = \dim \operatorname{null}(\boldsymbol{A}) + \operatorname{rank} \boldsymbol{A}.$$

秩计数独立的输出方向，零度计数被消去的独立输入方向，二者之和固定为输入维数。在示例 2.25中，$\dim \ker T = 1$、$\operatorname{rank} T = 3$，二者之和为输入维数 4。图 2.8再给出两个几何算例：被送到零的方向与实际用到的输出方向，维数相加恰为定义域的维数。

秩不超过矩阵的行数和列数：$\operatorname{rank} \boldsymbol{A} \le \min(m, d)$。这是因为列空间在 $\mathbb{R}^m$ 中，维数不超过 m；它又由 d 列张成，从中抽取的基不超过 d 个向量。$\operatorname{rank} \boldsymbol{A} = d$ 称为满列秩，这时输入方向全部保留，等价于各列线性无关；$\operatorname{rank} \boldsymbol{A} = m$ 称为满行秩，这时每个输出都可以到达。二者统称**满秩**（full rank）。

矩形矩阵不能同时满列秩和满行秩。$m < d$ 时，即使满行秩，核的维数也是 $d - m > 0$；$m > d$ 时，即使满列秩，像的维数也只有 $d < m$，总有输出无法到达。例如贯穿例 $\boldsymbol{X}_\varepsilon$ 在 $\varepsilon \neq 0$ 时两列线性无关（示例 2.8），秩为 2，满列秩；它的像是 $\mathbb{R}^3$ 中的一个平面，所以不是满行秩。

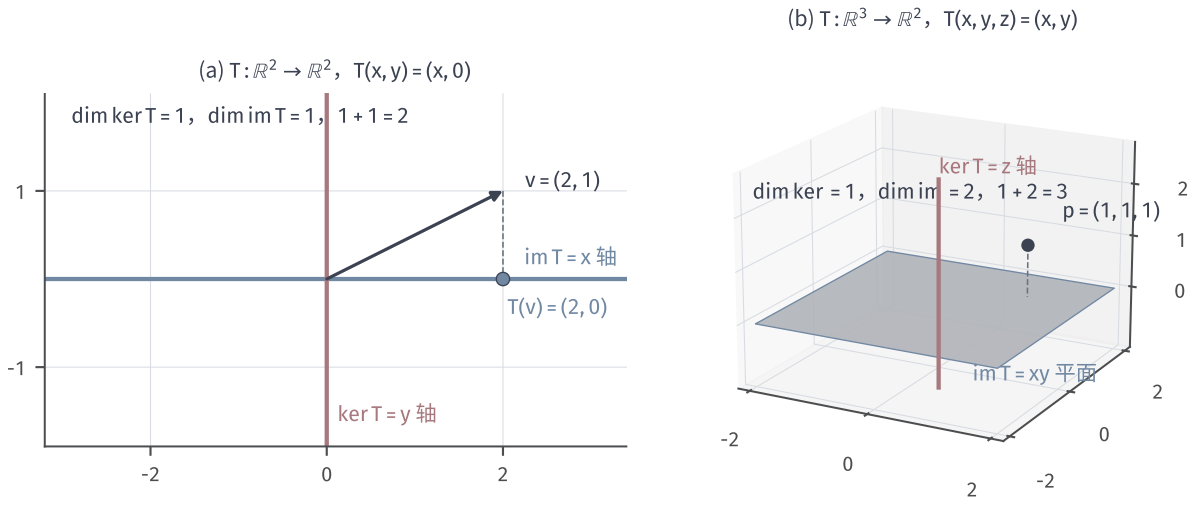


图 2.8 核与像的维数此消彼长。左：$T(x,y)=(x,0)$ 把平面映到 x 轴，核是 y 轴（红直线）、像是 x 轴（蓝直线），$\dim\ker T=1$、$\dim\operatorname{im} T=1$，$1+1=2$；样本 $\boldsymbol{v}=(2,1)$ 被映到 $(2,0)$。右：$T(x,y,z)=(x,y)$ 把三维空间映到 xy 平面，核是 z 轴（红直线）、像是整个 xy 平面（浅蓝），$\dim\ker T=1$、$\dim\operatorname{im} T=2$，$1+2=3$。两图为解析教学例。

商空间 前面看到，输出相同的输入恰好彼此相差一个核中的向量。按输出把输入分组，每组都形如 $\boldsymbol{x}+\ker T$，正是第 2.1.3节取 $U=\ker T$ 得到的等价类；全部分组组成商空间 $V/\ker T$。

规则 $\boldsymbol{x}+\ker T\mapsto T\boldsymbol{x}$ 不依赖代表元，因为代表元相差核中的向量时输出相同。它保持线性组合，并且满射到 $\operatorname{im} T$。它也是单射：两个类的像相同即 $T\boldsymbol{x}=T\boldsymbol{y}$ 时，$\boldsymbol{x}-\boldsymbol{y}\in\ker T$，两个类相同。所以它是从 $V/\ker T$ 到 $\operatorname{im} T$ 的线性双射。压去全部丢失的方向以后，每个等价类恰好对应一个可达输出。

线性双射把一组基送到一组基，所以两边维数相同。由式 (2.4)得 $\dim V-\dim\ker T=\operatorname{rank} T$，这是秩零度定理的另一种读法。在示例 2.25中，商空间 $\mathbb{R}^4/\ker T$ 是三维的，像 $\mathbb{R}^3$ 也是三维的。

证明行秩等于列秩 现在对一般的 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$ 证明示例 2.24中的维数规律。对 $\boldsymbol{A}$ 用秩零度定理，零空间与列空间的维数之和为 d；对 $\boldsymbol{A}^{\mathsf{T}}$ 用秩零度定理，左零空间与行空间的维数之和为 m。还需证明行空间与列空间的维数总相等。

定理 2.27 行秩等于列秩 对任意 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$，$\dim\operatorname{range}(\boldsymbol{A}^{\mathsf{T}})=\dim\operatorname{range}(\boldsymbol{A})$，即 $\operatorname{rank}\boldsymbol{A}^{\mathsf{T}}=\operatorname{rank}\boldsymbol{A}$。

证明 设 $r = \operatorname{rank} \boldsymbol{A}$，取列空间的一组基 $\boldsymbol{c}_1, \dots, \boldsymbol{c}_r$，排成 $\boldsymbol{C} \in \mathbb{R}^{m \times r}$。$\boldsymbol{A}$ 的每一列都在列空间中，所以第 j 列可写成 $\boldsymbol{A}_{:,j} = \boldsymbol{C}\boldsymbol{r}_j$，$\boldsymbol{r}_j \in \mathbb{R}^r$；把这些系数列排成 $\boldsymbol{R} \in \mathbb{R}^{r \times d}$，按乘积的列读法得 $\boldsymbol{A} = \boldsymbol{C}\boldsymbol{R}$。

再按行读这个乘积：$\boldsymbol{A}$ 的第 i 行是 $\boldsymbol{A}_{i,:} = \sum_{k=1}^{r} \boldsymbol{C}_{i,k} \boldsymbol{R}_{k,:}$，即 $\boldsymbol{R}$ 的 r 行的线性组合。所以 $\boldsymbol{A}$ 的全部行都落在 $\boldsymbol{R}$ 的 r 行张成的空间里，行空间的维数不超过 r，即 $\operatorname{rank} \boldsymbol{A}^{\top} \le \operatorname{rank} \boldsymbol{A}$。对 $\boldsymbol{A}^{\top}$ 用同样的论证，得 $\operatorname{rank} \boldsymbol{A} \le \operatorname{rank} \boldsymbol{A}^{\top}$，两者相等。 ■

于是行秩（行空间的维数）与列秩（列空间的维数）可以统称为秩。对 $\boldsymbol{A}$ 与 $\boldsymbol{A}^{\top}$ 分别用秩零度定理，四个基本子空间的维数全部由 m, d 与 $r = \operatorname{rank} \boldsymbol{A}$ 决定：

$$\begin{aligned} \dim \operatorname{range}(\boldsymbol{A}) &= \dim \operatorname{range}(\boldsymbol{A}^{\top}) = r, \\ \dim \operatorname{null}(\boldsymbol{A}) = d - r, &\qquad \dim \operatorname{null}(\boldsymbol{A}^{\top}) = m - r. \end{aligned} \tag{2.14}$$

输入空间中的零空间与行空间维数相加为 d，输出空间中的列空间与左零空间维数相加为 m。

对示例 2.24中的 $\boldsymbol{A}$，$r = 1$，式 (2.14)给出的维数与直接计算一致；证明中的分解 $\boldsymbol{A} = \boldsymbol{C}\boldsymbol{R}$ 在那里就是 $\boldsymbol{A} = (1,2)^{\top}(1,2,3)$。该示例还显示，两对子空间不仅维数互补，而且互相垂直，这要等第 3.5.1节有了内积才能说清。第 2.4.2节还将用对偶映射给出行秩等于列秩的另一个证明。

2.3.3 单射、满射与可逆性

由输出唯一还原输入，需要两个条件：不同的输入给出不同的输出（单射），每个输出都能到达（满射）。对线性映射，两个条件都可以用子空间判断。

单射等价于核为零。若核为零，由 $T\boldsymbol{x} = T\boldsymbol{y}$ 当且仅当 $\boldsymbol{x} - \boldsymbol{y} \in \ker T$，输出相同必有输入相同；反过来，若核中有非零向量，它与 $\boldsymbol{0}$ 的输出相同，映射就不是单射。

满射等价于像等于整个输出空间。在有限维情形，用秩零度定理可以把二者换成维数条件：单射当且仅当 $\operatorname{rank} T = \dim V$，满射当且仅当 $\operatorname{rank} T = \dim W$。

输入与输出维数相等时，三种性质合而为一。$\dim V = \dim W$ 时，$\ker T = \{\boldsymbol{0}\}$ 等价于 $\operatorname{rank} T = \dim V = \dim W$，所以单射、满射、双射互相等价，只需检查其中一条。

维数不同时则须分别判断：$\dim V < \dim W$ 时，像的维数至多为 $\dim V$，不可能满射；$\dim V > \dim W$ 时，核的维数至少为 $\dim V - \dim W > 0$，不可能单射。所以只有输入输出维数相等的映射才可能可逆；矩形矩阵即使满秩，也只能是单射或满射之一。

把这些判据与上一小节可逆映射和逆矩阵的对应合起来，对 n 阶方阵 $\boldsymbol{A}$，下列条件互相等价：

$$\boldsymbol{A}\text{可逆} \iff \operatorname{null}(\boldsymbol{A}) = \{\boldsymbol{0}\} \iff \operatorname{rank}\boldsymbol{A} = n \iff \boldsymbol{A}\text{的}n\text{列线性无关.}$$

其中后两个条件等价，是因为列空间由 n 列张成，维数为 n 恰好说明这 n 列构成它的一组基。由行秩等于列秩，还可以在链中加入“$\boldsymbol{A}$ 的 n 行线性无关”。第 9.1节还将用行列式给出等价的数值判据 $\det \boldsymbol{A} \neq 0$。

这一等价不借助行列式，就给出第 1.3.1.4节“方阵的单侧逆即逆”的另一个证明。若 n 阶方阵满足 $\boldsymbol{BA} = \boldsymbol{I}_n$，则 $\boldsymbol{Ax} = \boldsymbol{0}$ 蕴含 $\boldsymbol{x} = \boldsymbol{BAx} = \boldsymbol{0}$，核为零，所以 $\boldsymbol{A}$ 可逆，于是 $\boldsymbol{B} = \boldsymbol{BAA}^{-1} = \boldsymbol{A}^{-1}$；$\boldsymbol{AB} = \boldsymbol{I}_n$ 时对 $\boldsymbol{B}$ 作同样论证。

同理，若 n 阶方阵的乘积 $\boldsymbol{AB}$ 可逆，则两个因子都可逆。$\boldsymbol{Bx} = \boldsymbol{0}$ 蕴含 $\boldsymbol{ABx} = \boldsymbol{0}$，从而 $\boldsymbol{x} = \boldsymbol{0}$，$\boldsymbol{B}$ 的核为零，因而可逆；于是 $\boldsymbol{A} = (\boldsymbol{AB})\boldsymbol{B}^{-1}$ 是可逆矩阵的乘积，也可逆。

下面先看最容易还原的逐坐标缩放，再看一个把坐标掺在一起的矩阵；两者用的判据相同：方阵的核是否为零。

示例 2.28　用核判断可逆　对角矩阵 $\operatorname{diag}(d_1, \dots, d_n)$ 逐坐标缩放，坐标之间互不影响。若每个 $d_i \neq 0$，逐坐标除以 d_i 即可撤销，逆矩阵为 $\operatorname{diag}(1/d_1, \dots, 1/d_n)$。若某个 $d_i = 0$，相应坐标被压为零，$\boldsymbol{e}_i$ 落入核中，两个只在第 i 个坐标不同的输入给出相同输出，无法还原。所以对角矩阵可逆当且仅当全部 $d_i \neq 0$。

矩阵

$$\boldsymbol{A} = \begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix}$$

把两个坐标掺在一起，不能逐坐标撤销，但判据照样适用。$\boldsymbol{Ax} = \boldsymbol{0}$ 即 $2x_1 + x_2 = 0$ 与 $3x_2 = 0$；第二式给出 $x_2 = 0$，代入第一式得 $x_1 = 0$，所以核为零。$\boldsymbol{A}$ 是方阵且核为零，因而可逆，它的逆矩阵已在第 1.2.8节求出。

单侧逆　维数不同时，仍可以撤销一半。单射 $T : V \to W$ 有线性映射 $L : W \to V$ 使 $L \circ T = \mathrm{id}_V$：在像上按 T 的逆读回输入，在像的一个补空间上任意规定（例如送到零）。满射 T 有线性映射 $R : W \to V$ 使 $T \circ R = \mathrm{id}_W$：为输出基中的每个向量任选一个原输入，再线性延拓。补空间与原输入的选法不唯一，所以这些单侧逆一般也不唯一。

写成矩阵，对 $\boldsymbol{A} \in \mathbb{R}^{m \times d}$：$\boldsymbol{A}$ 有左逆当且仅当它满列秩，有右逆当且仅当它满行秩。充分性来自上面的构造，因为满列秩就是单射，满行秩就是满射。必要性也直接：若 $\boldsymbol{LA} = \boldsymbol{I}_d$，则 $\boldsymbol{Ax} = \boldsymbol{0}$ 蕴含 $\boldsymbol{x} = \boldsymbol{LAx} = \boldsymbol{0}$，核为零；

若 $\boldsymbol{A}\boldsymbol{R}=\boldsymbol{I}_m$，则每个 $\boldsymbol{y}=\boldsymbol{A}(\boldsymbol{R}\boldsymbol{y})$ 都可到达。第 1.2.8节的例子 $\boldsymbol{A}=(1,0)^{\mathsf{T}}$ 满列秩，有无穷多个左逆。有多个选择时怎样选出代表，由第 9章回答。

2.3.4 换基、矩阵等价与相似

第 2.2.4节看到，同一个对象在不同基下有不同的坐标。同样，同一个线性映射换一组基，记录它的矩阵通常也随之改变。坐标变换、矩阵表示与逆矩阵现在都已具备，本小节写出这种变化，并判断两个矩阵何时记录同一个映射。

先讨论一般映射，再讨论算子。一般映射的两端是两个空间，可以各自换基，相应的矩阵关系称为相抵。算子两端是同一个空间，换基时两端必须一起变，相应的关系称为相似；它是相抵加上“两端换基相同”这一约束的特例。约束减少了可用的自由度：相抵只需秩就能完全分类，相似却需要更多不变量。

推导要用到一个观察：换基矩阵本身就是一个线性映射的矩阵。比较式 (2.7)与式 (2.9)可见，$\boldsymbol{S}_{\mathcal{C}\leftarrow\mathcal{B}}$ 正是恒等映射 id_V 在输入基 $\mathcal{B}$、输出基 $\mathcal{C}$ 下的矩阵：对象不动，只是输入端与输出端用不同的基记录。连续换基的乘法公式，就是复合公式 (2.10)用于 $\mathrm{id}_V\circ\mathrm{id}_V=\mathrm{id}_V$ 的特例。

2.3.4.1 一般线性映射的换基与相抵

设 $T:V\to W$ 是线性映射，$\dim V=d$、$\dim W=m$。本小节先求出 T 在两对基下的矩阵之间的关系，再证明这一关系恰好刻画了“两个同形矩阵记录同一个映射”，最后说明秩是判断相抵的唯一依据。

换基过程　设 $\mathcal{B},\mathcal{B}'$ 是 V 的两组基，$\mathcal{C},\mathcal{C}'$ 是 W 的两组基，记 $\boldsymbol{A}=[T]_{\mathcal{C}\leftarrow\mathcal{B}}$、$\boldsymbol{B}=[T]_{\mathcal{C}'\leftarrow\mathcal{B}'}$。输入端换基矩阵为 $\boldsymbol{P}=\boldsymbol{S}_{\mathcal{B}\leftarrow\mathcal{B}'}$（$d$ 阶可逆），输出端换基矩阵为 $\boldsymbol{Q}=\boldsymbol{S}_{\mathcal{C}\leftarrow\mathcal{C}'}$（$m$ 阶可逆）。$\boldsymbol{P}$ 的第 j 列是新输入基向量在旧输入基下的坐标，$\boldsymbol{Q}$ 同理。已知新输入坐标 $[\boldsymbol{v}]_{\mathcal{B}'}$，可以绕道旧基，分三步求出新输出坐标 $[T\boldsymbol{v}]_{\mathcal{C}'}$。

第一步，把新输入坐标换成旧输入坐标：$[\boldsymbol{v}]_{\mathcal{B}}=\boldsymbol{P}[\boldsymbol{v}]_{\mathcal{B}'}$。第二步，在旧基下作用：$[T\boldsymbol{v}]_{\mathcal{C}}=\boldsymbol{A}[\boldsymbol{v}]_{\mathcal{B}}=\boldsymbol{A}\boldsymbol{P}[\boldsymbol{v}]_{\mathcal{B}'}$。第三步，用反向换基矩阵 $\boldsymbol{Q}^{-1}=\boldsymbol{S}_{\mathcal{C}'\leftarrow\mathcal{C}}$ 把旧输出坐标换成新输出坐标：

$$[T\boldsymbol{v}]_{\mathcal{C}'}=\boldsymbol{Q}^{-1}[T\boldsymbol{v}]_{\mathcal{C}}=\boldsymbol{Q}^{-1}\boldsymbol{A}\boldsymbol{P}[\boldsymbol{v}]_{\mathcal{B}'}.$$

另一方面，按定义 $[T\boldsymbol{v}]_{\mathcal{C}'}=\boldsymbol{B}[\boldsymbol{v}]_{\mathcal{B}'}$。两式对每个 $\boldsymbol{v}$ 成立。取 $\boldsymbol{v}=\boldsymbol{b}'_j$，其新坐标为 $\boldsymbol{e}_j$，两边读出的是两个矩阵的第 j 列，所以

$$\boldsymbol{B}=\boldsymbol{Q}^{-1}\boldsymbol{A}\boldsymbol{P}. \tag{2.15}$$

从右向左读：$\boldsymbol{P}$ 把新输入坐标换成旧坐标，$\boldsymbol{A}$ 在旧基下作用，$\boldsymbol{Q}^{-1}$ 把结果换成新输出坐标。用复合的语言说，$T = \mathrm{id}_W \circ T \circ \mathrm{id}_V$，三个因子分别在相应的基下记录，由式 (2.10)就得到上式右端的三个矩阵。

相抵的定义　上面的推导说明，同一映射的两个记录之间只相差两侧各乘一个可逆矩阵。把这种关系单独命名。

> **定义 2.29　矩阵相抵**　设 $\boldsymbol{A}, \boldsymbol{B} \in \mathbb{R}^{m\times d}$。若存在可逆矩阵 $\boldsymbol{Q} \in \mathbb{R}^{m\times m}$ 与 $\boldsymbol{P} \in \mathbb{R}^{d\times d}$ 使 $\boldsymbol{B} = \boldsymbol{Q}^{-1}\boldsymbol{A}\boldsymbol{P}$，就称 $\boldsymbol{A}$ 与 $\boldsymbol{B}$**相抵**（equivalent matrices）。

定义中的 $\boldsymbol{Q}, \boldsymbol{P}$ 可以是任意可逆矩阵，不必事先知道它们来自哪组基。写成 $\boldsymbol{Q}^{-1}$ 只是为了与换基推导一致；$\boldsymbol{Q}$ 取遍全部可逆矩阵时，$\boldsymbol{Q}^{-1}$ 也取遍全部可逆矩阵。

相抵恰好刻画“记录同一个映射”。一个方向已由换基推导给出。另一个方向，设 $\boldsymbol{A} = [T]_{\mathcal{C}\leftarrow\mathcal{B}}$，任给可逆的 $\boldsymbol{P}, \boldsymbol{Q}$。由第 2.2.4节，以 $\boldsymbol{P}$ 的各列为旧基坐标，可以得到 V 的一组新基 $\mathcal{B}'$，使 $\boldsymbol{S}_{\mathcal{B}\leftarrow\mathcal{B}'} = \boldsymbol{P}$；输出端用 $\boldsymbol{Q}$ 同样构造 $\mathcal{C}'$。由换基推导，T 在这两组新基下的矩阵恰为 $\boldsymbol{Q}^{-1}\boldsymbol{A}\boldsymbol{P}$。所以两个同形矩阵相抵，当且仅当它们是同一个线性映射在两端不同选基下的记录。右乘 $\boldsymbol{P}$ 对应更换输入基，左乘 $\boldsymbol{Q}^{-1}$ 对应更换输出基；初等列变换与初等行变换分别是这两种换基的具体实现。

相抵不变量　相抵的矩阵记录同一个映射，所以映射本身的性质不随基改变。先确认相抵是等价关系：自反取 $\boldsymbol{Q} = \boldsymbol{P} = \boldsymbol{I}$；对称由 $\boldsymbol{A} = \boldsymbol{Q}\boldsymbol{B}\boldsymbol{P}^{-1} = (\boldsymbol{Q}^{-1})^{-1}\boldsymbol{B}\boldsymbol{P}^{-1}$；传递由 $\boldsymbol{C} = \boldsymbol{Q}_2^{-1}\boldsymbol{B}\boldsymbol{P}_2 = (\boldsymbol{Q}_1\boldsymbol{Q}_2)^{-1}\boldsymbol{A}(\boldsymbol{P}_1\boldsymbol{P}_2)$。三条分别对应不换基、换回原基和连续换两次基。

再看哪些量保持不变。零空间在输入端被搬运：$\boldsymbol{B}\boldsymbol{x} = \boldsymbol{0}$ 当且仅当 $\boldsymbol{A}(\boldsymbol{P}\boldsymbol{x}) = \boldsymbol{0}$，所以 $\operatorname{null}(\boldsymbol{B}) = \boldsymbol{P}^{-1}\operatorname{null}(\boldsymbol{A})$。列空间在输出端被搬运：$\boldsymbol{B}\boldsymbol{x} = \boldsymbol{Q}^{-1}\boldsymbol{A}(\boldsymbol{P}\boldsymbol{x})$，而 $\boldsymbol{P}\boldsymbol{x}$ 取遍全部输入，所以 $\operatorname{range}(\boldsymbol{B}) = \boldsymbol{Q}^{-1}\operatorname{range}(\boldsymbol{A})$。可逆矩阵把线性无关组送到线性无关组，搬运不改变子空间的维数，因此

$$\begin{aligned} \operatorname{rank}\boldsymbol{B} &= \operatorname{rank}\boldsymbol{A} \\ \dim\operatorname{null}(\boldsymbol{B}) &= \dim\operatorname{null}(\boldsymbol{A}) = d - \operatorname{rank}\boldsymbol{A}. \end{aligned} \tag{2.16}$$

相抵允许的记录变化很宽：输入与输出可以是不同空间，$\boldsymbol{B}$ 一般不是方阵，不能对自身反复作用，所以幂、迹这类只对算子有意义的量不在讨论之列。

相抵的判定　反过来，秩相同的两个同形矩阵一定相抵。证明的办法是：两端可以各自选基时，每个矩阵都能化成只由秩决定的简单形状。

设 $\boldsymbol{A}$ 是 T 在某对基下的矩阵，$r = \operatorname{rank}\boldsymbol{A}$。取 $\ker T$ 的一组基并扩充为 V 的基；由秩零度定理，新增向量恰有 r 个，把它们排在前面。这 r 个向量的像线性无关：若像的某个组合为零，相应的新增向量组合就落进核，能由核的基表示，整组基的线性无关性迫使系数全为零。

核的基向量的像都是零，所以这 r 个像还张成 $\operatorname{im} T$。再把这 r 个像扩充为 W 的基。在这样选取的两组基下，T 把前 r 个输入基向量依次送到前 r 个输出基向量，其余输入基向量送到零，矩阵为秩标准形

$$\begin{bmatrix} \boldsymbol{I}_r & \boldsymbol{0} \\ \boldsymbol{0} & \boldsymbol{0} \end{bmatrix}, \qquad r = \operatorname{rank}\boldsymbol{A}. \tag{2.17}$$

下面对一个秩为 1 的二阶矩阵具体做出这两组基。

示例 2.30　两端各自选基化为秩标准形　设 $T\boldsymbol{x} = \boldsymbol{A}\boldsymbol{x}$，其中

$$\boldsymbol{A} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix},$$

两端原来都用标准基。两列共线，$\operatorname{rank}\boldsymbol{A} = 1$；又 $\boldsymbol{A}(-2,1)^{\mathsf{T}} = \boldsymbol{0}$，所以 $\ker T = \operatorname{span}\{(-2,1)^{\mathsf{T}}\}$。

按上面的构造选基。输入端把核的基向量 $\boldsymbol{v}_2 = (-2,1)^{\mathsf{T}}$ 放在后面，前面补一个不在核中的 $\boldsymbol{v}_1 = \boldsymbol{e}_1$；输出端先取它的像 $\boldsymbol{w}_1 = \boldsymbol{A}\boldsymbol{v}_1 = (1,2)^{\mathsf{T}}$，再补上 $\boldsymbol{w}_2 = \boldsymbol{e}_2$ 凑成一组基。以新基向量的标准坐标为列，得到两端的换基矩阵

$$\boldsymbol{P} = \begin{bmatrix} 1 & -2 \\ 0 & 1 \end{bmatrix}, \qquad \boldsymbol{Q} = \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix}, \qquad \boldsymbol{Q}^{-1} = \begin{bmatrix} 1 & 0 \\ -2 & 1 \end{bmatrix}.$$

先算 $\boldsymbol{A}\boldsymbol{P}$，它的两列就是 $\boldsymbol{v}_1, \boldsymbol{v}_2$ 的像的标准坐标：

$$\boldsymbol{A}\boldsymbol{P} = \begin{bmatrix} 1 & 0 \\ 2 & 0 \end{bmatrix}.$$

再左乘 $\boldsymbol{Q}^{-1}$，把这两个像改用输出基 $\boldsymbol{w}_1, \boldsymbol{w}_2$ 记录：

$$\boldsymbol{Q}^{-1}\boldsymbol{A}\boldsymbol{P} = \begin{bmatrix} 1 & 0 \\ -2 & 1 \end{bmatrix}\begin{bmatrix} 1 & 0 \\ 2 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

结果正是秩标准形 $\operatorname{diag}(1,0)$：在新基下，T 把 $\boldsymbol{v}_1$ 送到 $\boldsymbol{w}_1$，把核方向 $\boldsymbol{v}_2$ 送到零。

图 2.9画出这两组基：$\boldsymbol{v}_1$ 被送到 $\boldsymbol{w}_1$，核方向 $\boldsymbol{v}_2$ 被送到零，输出端的 $\boldsymbol{w}_2$ 不被任何输入到达。只有两端各自选基，才能同时做到这几点；若要求两端用同一组基，这一化简一般做不到。

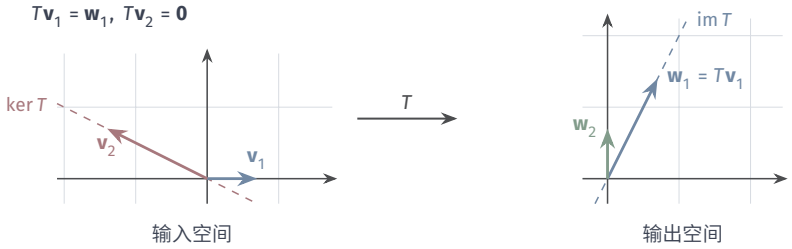


图 2.9　两端各自选基化为秩标准形。$T(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x}$，$\boldsymbol{A} = \left[\begin{smallmatrix}1 & 2\\ 2 & 4\end{smallmatrix}\right]$。左：输入基 $\boldsymbol{v}_1 = \boldsymbol{e}_1$（蓝）与 $\boldsymbol{v}_2 = (-2,1)^{\mathsf{T}}$（红），$\boldsymbol{v}_2$ 在核（红虚线）上。右：输出基 $\boldsymbol{w}_1 = T\boldsymbol{v}_1 = (1,2)^{\mathsf{T}}$（蓝）位于像（蓝虚线）上，$\boldsymbol{w}_2 = \boldsymbol{e}_2$（绿）补足一组基。在这两组基下 T 的矩阵为 $\mathrm{diag}(1,0)$。

由秩标准形即得相抵的完整判据。

定理 2.31　相抵判据　两个同形实矩阵 $\boldsymbol{A},\boldsymbol{B} \in \mathbb{R}^{m\times d}$ 相抵，当且仅当 $\operatorname{rank}\boldsymbol{A} = \operatorname{rank}\boldsymbol{B}$。

证明　必要性由式(2.16)得到。充分性：设二者秩都为 r，由上面的构造，存在可逆矩阵使 $\boldsymbol{R} = \boldsymbol{Q}_A^{-1}\boldsymbol{A}\boldsymbol{P}_A = \boldsymbol{Q}_B^{-1}\boldsymbol{B}\boldsymbol{P}_B$，其中 $\boldsymbol{R}$ 是式(2.17)的秩标准形。两式对接得 $\boldsymbol{B} = (\boldsymbol{Q}_A\boldsymbol{Q}_B^{-1})^{-1}\boldsymbol{A}(\boldsymbol{P}_A\boldsymbol{P}_B^{-1})$，即二者相抵。 ■

所以固定形状以后，秩就是相抵的完整不变量：零矩阵只与零矩阵相抵，同形的满秩矩阵彼此相抵。把矩阵化到标准形，具体可以用第 1.2.7节的初等行变换配合初等列变换完成；数值计算中的消元算法在第 10章建立。

2.3.4.2　线性算子的换基与相似

线性算子 $T : V \to V$ 的输入与输出是同一个空间，记录时两端用同一组基，换基时两端也换成同一组新基。本小节把这一约束加进上面的推导，得到相似关系，再讨论相似保持哪些量，以及怎样判断两个方阵是否相似。

换基过程　设 $\mathcal{B}$ 与 $\mathcal{B}'$ 是 V 的两组基，$\boldsymbol{A} = [T]_{\mathcal{B}}$、$\boldsymbol{B} = [T]_{\mathcal{B}'}$，记 $\boldsymbol{P} = \boldsymbol{S}_{\mathcal{B}\leftarrow\mathcal{B}'}$。它的第 j 列是新基向量 $\boldsymbol{b}'_j$ 在旧基 $\mathcal{B}$ 下的坐标；$\boldsymbol{P}$ 可逆，反向换基矩阵为 $\boldsymbol{P}^{-1}$。输入端与输出端是同一个空间、同一次换基，所以三步推导中的 $\boldsymbol{Q}$ 也是 $\boldsymbol{P}$。

先把新坐标换成旧坐标，$[\boldsymbol{v}]_{\mathcal{B}} = \boldsymbol{P}[\boldsymbol{v}]_{\mathcal{B}'}$；在旧基下作用，$[T\boldsymbol{v}]_{\mathcal{B}} = \boldsymbol{A}\boldsymbol{P}[\boldsymbol{v}]_{\mathcal{B}'}$；再把输出换回新坐标，

$$[T\boldsymbol{v}]_{\mathcal{B}'} = \boldsymbol{P}^{-1}[T\boldsymbol{v}]_{\mathcal{B}} = \boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P}[\boldsymbol{v}]_{\mathcal{B}'}.$$

与 $[T\boldsymbol{v}]_{\mathcal{B}'} = \boldsymbol{B}[\boldsymbol{v}]_{\mathcal{B}'}$ 逐列比较，得到

$$\boldsymbol{B} = \boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P}. \tag{2.18}$$

这就是式 (2.15)取 $\boldsymbol{Q} = \boldsymbol{P}$ 的情形。

相似的定义 与相抵一样，给同一算子两个记录之间的关系单独命名。

定义 2.32 矩阵相似 设 $\boldsymbol{A}, \boldsymbol{B}$ 是 n 阶方阵。若存在 n 阶可逆矩阵 $\boldsymbol{P}$ 使 $\boldsymbol{B} = \boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P}$，就称 $\boldsymbol{A}$ 与 $\boldsymbol{B}$**相似**（similar）。

相似的两个矩阵正是同一个线性算子在两组基下的记录。一个方向由上面的推导给出。另一个方向，给定 $\boldsymbol{A} = [T]_{\mathcal{B}}$ 和可逆的 $\boldsymbol{P}$，以 $\boldsymbol{P}$ 的各列为旧基坐标得到一组新基，T 在这组基下的矩阵恰为 $\boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P}$。

相似不要求 $\boldsymbol{A}, \boldsymbol{B}$ 本身可逆，可逆的只是换基矩阵 $\boldsymbol{P}$。取 $\boldsymbol{Q} = \boldsymbol{P}$ 可见，相似的矩阵必定相抵；反之不然，后面的示例 2.34给出秩相同、因而相抵却不相似的两个矩阵。

适当换基可以简化算子的矩阵。下面的例子把一个上三角矩阵化成对角形。

示例 2.33 换基把算子的矩阵化为对角形 示例 2.21中的算子 $T(x_1, x_2) = (2x_1 + x_2, 3x_2)$ 在标准基下的矩阵为

$$\boldsymbol{A} = \begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix},$$

即 $T\boldsymbol{e}_1 = 2\boldsymbol{e}_1$、$T\boldsymbol{e}_2 = \boldsymbol{e}_1 + 3\boldsymbol{e}_2$。$\boldsymbol{e}_1$ 只被伸长，$\boldsymbol{e}_2$ 的像却混入了 $\boldsymbol{e}_1$ 方向，这就是非对角元 1 的来源。改取新基 $\boldsymbol{b}_1' = \boldsymbol{e}_1$、$\boldsymbol{b}_2' = \boldsymbol{e}_1 + \boldsymbol{e}_2$，换基矩阵以新基向量的标准坐标为列，它和它的逆为

$$\boldsymbol{P} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}, \quad \boldsymbol{P}^{-1} = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix},$$

于是

$$\boldsymbol{B} = \boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P} = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix}\begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix}\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}.$$

不经矩阵乘法也能看出这一结果：$T\boldsymbol{b}_1' = 2\boldsymbol{b}_1'$，$T\boldsymbol{b}_2' = T\boldsymbol{e}_1 + T\boldsymbol{e}_2 = 3\boldsymbol{e}_1 + 3\boldsymbol{e}_2 = 3\boldsymbol{b}_2'$。两个新基方向在 T 的作用下都只被伸缩、不被转向，彼此互不干扰，所以 T 在新基下的矩阵是对角矩阵 $\mathrm{diag}(2,3)$。

T 本身没有改变，改变的只是沿哪两个方向读取。图 2.10把这一点画在平面上。在标准基下，单位正方形被 T 拉成一个斜的平行四边形，矩阵 $\boldsymbol{A}$ 有非零的非对角元。在新基下，基向量围成的平行四边形只沿两个基方向分别伸长 2 倍和 3 倍，矩阵就是对角的 $\boldsymbol{B}$。

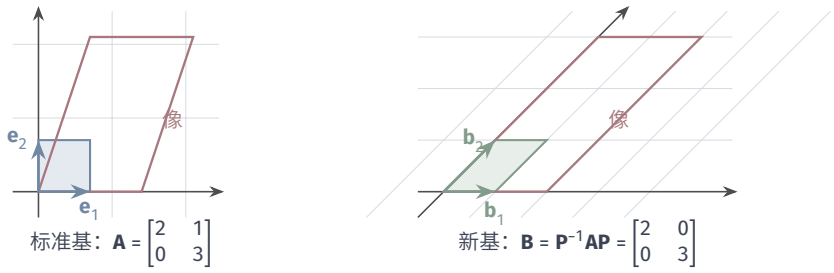


图 2.10　同一个算子在两组基下的记录。左：标准基 $\boldsymbol{e}_1, \boldsymbol{e}_2$ 围成的单位正方形（蓝）被 $\boldsymbol{A} = \left[\begin{smallmatrix} 2 & 1 \\ 0 & 3 \end{smallmatrix}\right]$ 送到红色平行四边形，形状被斜切。右：新基 $\boldsymbol{b}_1 = \boldsymbol{e}_1$、$\boldsymbol{b}_2 = \boldsymbol{e}_1 + \boldsymbol{e}_2$ 围成的平行四边形（绿）被同一个算子送到红色平行四边形，只沿 $\boldsymbol{b}_1$ 伸长 2 倍、沿 $\boldsymbol{b}_2$ 伸长 3 倍，因此新矩阵为 $\mathrm{diag}(2,3)$。浅色斜线为新基网格。

相似不变量　同一个算子的性质不随基改变，下面找出相似保持的量。相似首先是等价关系：$\boldsymbol{A} = \boldsymbol{I}^{-1}\boldsymbol{A}\boldsymbol{I}$ 给出自反性；由 $\boldsymbol{B} = \boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P}$ 得 $\boldsymbol{A} = \boldsymbol{P}\boldsymbol{B}\boldsymbol{P}^{-1}$，给出对称性；若再有 $\boldsymbol{C} = \boldsymbol{Q}^{-1}\boldsymbol{B}\boldsymbol{Q}$，则 $\boldsymbol{C} = (\boldsymbol{P}\boldsymbol{Q})^{-1}\boldsymbol{A}(\boldsymbol{P}\boldsymbol{Q})$，给出传递性。这三条分别对应不换基、换回原基和连续换两次基。

相似是相抵的特例，相抵不变量自然保持：$\mathrm{null}(\boldsymbol{B}) = \boldsymbol{P}^{-1}\,\mathrm{null}(\boldsymbol{A})$，$\mathrm{range}(\boldsymbol{B}) = \boldsymbol{P}^{-1}\,\mathrm{range}(\boldsymbol{A})$，因此

$$\begin{aligned} \operatorname{rank}\boldsymbol{B} &= \operatorname{rank}\boldsymbol{A} \\ \dim\mathrm{null}(\boldsymbol{B}) &= \dim\mathrm{null}(\boldsymbol{A}). \end{aligned} \tag{2.19}$$

算子还能反复作用，而反复作用与换基相容。若 $\boldsymbol{B}_1 = \boldsymbol{P}^{-1}\boldsymbol{A}_1\boldsymbol{P}$、$\boldsymbol{B}_2 = \boldsymbol{P}^{-1}\boldsymbol{A}_2\boldsymbol{P}$，则

$$\boldsymbol{B}_1\boldsymbol{B}_2 = \boldsymbol{P}^{-1}\boldsymbol{A}_1\boldsymbol{P}\,\boldsymbol{P}^{-1}\boldsymbol{A}_2\boldsymbol{P} = \boldsymbol{P}^{-1}\boldsymbol{A}_1\boldsymbol{A}_2\boldsymbol{P}, \tag{2.20}$$

中间的 $\boldsymbol{P}\boldsymbol{P}^{-1}$ 相消。归纳得 $\boldsymbol{B}^k = \boldsymbol{P}^{-1}\boldsymbol{A}^k\boldsymbol{P}$：在新基下，反复作用同一个算子仍记录同一个过程。同样，对任意实数 c，$\boldsymbol{B} - c\boldsymbol{I} = \boldsymbol{P}^{-1}(\boldsymbol{A} - c\boldsymbol{I})\boldsymbol{P}$，所以 $\boldsymbol{A} - c\boldsymbol{I}$ 与 $\boldsymbol{B} - c\boldsymbol{I}$ 也相似。由式 (2.19)，

$$\operatorname{rank}(\boldsymbol{B} - c\boldsymbol{I}) = \operatorname{rank}(\boldsymbol{A} - c\boldsymbol{I}), \qquad c \in \mathbb{R}. \tag{2.21}$$

这比单看秩更细：每个 c 都给出一个不变量。

相似还保持两个可以直接计算的标量。由行列式的乘法性（第 1.3.1节）与 $\det(\boldsymbol{P}^{-1})\det\boldsymbol{P} = \det\boldsymbol{I} = 1$，

$$\det(\boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P}) = \det(\boldsymbol{P}^{-1})\,\det\boldsymbol{A}\,\det\boldsymbol{P} = \det\boldsymbol{A};$$

由迹的循环性（式 (1.12)），

$$\operatorname{tr}(\boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P}) = \operatorname{tr}\big((\boldsymbol{A}\boldsymbol{P})\boldsymbol{P}^{-1}\big) = \operatorname{tr}\boldsymbol{A}.$$

所以行列式与迹只依赖算子本身，可以用来检验两个矩阵能否记录同一个算子。例如示例 2.33中的 $\boldsymbol{A}$ 与 $\boldsymbol{B} = \operatorname{diag}(2,3)$ 行列式都是 6，迹都是 5。于是可以说“算子 T 的行列式”“算子 T 的迹”，用任意一组基下的矩阵计算即可。

引入特征值以后还将看到（第 4.1.4节），特征值与特征多项式同样是相似不变量，而行列式与迹恰好是特征值之积与特征值之和。一般的换基不保持欧氏长度与夹角，这些度量量不是相似不变量。

相似的判定 要判断两个给定的方阵是否相似，可以把定义改写成线性方程。两端左乘 $\boldsymbol{P}$，相似等价于存在可逆的 $\boldsymbol{P}$ 满足

$$\boldsymbol{A}\boldsymbol{P} = \boldsymbol{P}\boldsymbol{B}. \tag{2.22}$$

这是关于 $\boldsymbol{P}$ 各元素的一组线性方程。只找到非零但不可逆的解还不够：那只是两个坐标子空间之间的对应，不是两组基之间的换基。

不变量给出否定的判据：只要某个相似不变量不同，两个矩阵就不相似。但秩、行列式、迹相同都只是相似的必要条件，下面的例子说明它们合在一起也不充分。

示例 2.34　反例：相抵而不相似的两个矩阵 比较 $\boldsymbol{I}_2$ 与

$$\boldsymbol{J} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}.$$

前面列出的不变量都分不开它们：二者都可逆，秩都为 2，由相抵判据它们相抵；行列式都是 1，迹都是 2。移位后的秩却不同。取 $c=1$，$\boldsymbol{I}_2-\boldsymbol{I}_2=\boldsymbol{0}$ 的秩为 0，而

$$\boldsymbol{J}-\boldsymbol{I}_2=\begin{bmatrix}0 & 1\\ 0 & 0\end{bmatrix}$$

的秩为 1，式 (2.21)不成立，所以二者不相似。

这个结论也可以直接看出：若 $\boldsymbol{J}=\boldsymbol{P}^{-1}\boldsymbol{I}_2\boldsymbol{P}$，则 $\boldsymbol{J}=\boldsymbol{P}^{-1}\boldsymbol{P}=\boldsymbol{I}_2$，矛盾。单位矩阵在任何基下都是单位矩阵，只与自己相似；$\boldsymbol{J}$ 与它相抵，秩、行列式与迹也都相同，却不是同一个算子的记录。

这是“两端换基相同”这一约束的代价：相抵时秩相同就足够，相似时连秩、行列式与迹一起相同都不够。比较 $\boldsymbol{A}-c\boldsymbol{I}$ 在各个 c 处的秩是更细的必要条件；完整的相似分类需要 Jordan 标准形，本书不展开。

2.3.5 多线性映射

前面的线性映射只有一个输入。矩阵的元素内积、两个向量的外积都有两个输入：固定其中一个、改变另一个时，结果保持线性组合。描述这种逐个输入的线性，要为每个输入保留一个独立的位置，称为槽位。

设 $V_1,\dots,V_k,W$ 是同一数域上的线性空间。若映射 $F:V_1\times\cdots\times V_k\to W$ 在固定其余输入后，对每一个输入都是线性的，就称为多线性映射；$k=2$ 时称为双线性映射。例如 $F(\boldsymbol{x},\boldsymbol{y})=\boldsymbol{x}\boldsymbol{y}^{\mathsf{T}}$ 对两个输入分别线性。

对每个输入分别线性，不等于把输入组看成一个整体后线性。以实数乘法 $f(x,y)=xy$ 为例，$f(1,1)+f(1,1)=2$，但 $f(2,2)=4$。

选定各输入空间的基后，多线性映射也能由有限组系数记录。以实双线性函数 $B:V\times W\to\mathbb{R}$ 为例，取基 $(\boldsymbol{v}_i)$ 与 $(\boldsymbol{w}_j)$，令 $b_{i,j}=B(\boldsymbol{v}_i,\boldsymbol{w}_j)$。当 $\boldsymbol{x}=\sum_i x_i\boldsymbol{v}_i$、$\boldsymbol{y}=\sum_j y_j\boldsymbol{w}_j$ 时，逐个槽位展开得到

$$B(\boldsymbol{x},\boldsymbol{y})=\sum_{i,j}x_iy_jb_{i,j}.$$

因此，基向量两两配对的值足以确定任意输入下的值。换基会改变这些系数，映射本身不变。这组系数就是第 1.4.2节张量积与指标缩约所用的系数数组：上式右端正是系数表 $(b_{i,j})$ 与两列坐标的张量积 $[\boldsymbol{x}]\otimes[\boldsymbol{y}]$ 的 Frobenius 配对。不过，重排数组的存放次序只改变存放方式，不等于更换坐标基；换基改变的是系数表本身的数值。

2.4 对偶空间

线性映射把对象送到另一个空间。还有一类更简单的作用，只把对象读成一个数：取多项式在某一点的值，取信号的第一个样本，计算一组特征的加权和。第 2.2.4节的每个坐标 x_j 也是这样的读取。第 1章在 $\mathbb{R}^d$ 上用内积 $\langle \boldsymbol{w}, \boldsymbol{x} \rangle$ 表示加权读取，读取规则借一个向量 $\boldsymbol{w}$ 写出；一般空间上还没有内积，需要把读取规则本身当作研究对象。

本节先说明全部线性读取组成一个线性空间，即对偶空间，并用坐标读取构造它的基；再研究对象经过线性映射以后，输出端的读取怎样传回输入端。这种传回在坐标下就是转置，它给第 1章“行列互换”的操作一个不依赖坐标的含义。本节只用到线性运算；读取规则的大小需要范数，留到下一章。

2.4.1 线性泛函与对偶基

线性泛函 保持线性组合的标量读取称为**线性泛函** (linear functional)，即满足

$$\varphi(a\boldsymbol{x} + b\boldsymbol{y}) = a\varphi(\boldsymbol{x}) + b\varphi(\boldsymbol{y}), \qquad \boldsymbol{x}, \boldsymbol{y} \in V,\ a, b \in \mathbb{R}$$

的映射 $\varphi : V \to \mathbb{R}$。它就是陪域为 $\mathbb{R}$ 的线性映射。在 P_k 上，取值 $p \mapsto p(t_0)$ 与积分 $p \mapsto \int_0^1 p(t)\,\mathrm{d}t$ 都是线性泛函；在 $\mathbb{R}^d$ 上，读取第 j 个坐标与加权和 $\boldsymbol{x} \mapsto \boldsymbol{a}^{\mathsf{T}}\boldsymbol{x}$ 都是线性泛函。但并非每个把向量读成一个数的规则都是线性泛函。

> **示例 2.35 反例：两个非线性的读取** 考虑 $\mathbb{R}^d$ 上的两个读取：$\varphi_1(\boldsymbol{x}) = x_1 + 1$ 把第一个坐标加上 1，$\varphi_2(\boldsymbol{x}) = \|\boldsymbol{x}\|_2$ 读出长度。线性泛函必把零向量读成 0，而 $\varphi_1(\boldsymbol{0}) = 1$，常数项已经破坏了线性。$\varphi_2$ 在零向量处读数为 0，问题出在符号上：线性泛函满足 $\varphi(-\boldsymbol{x}) = -\varphi(\boldsymbol{x})$，但对任一 $\boldsymbol{x} \neq \boldsymbol{0}$，$\varphi_2(-\boldsymbol{x}) = \|\boldsymbol{x}\|_2 > 0$，而 $-\varphi_2(\boldsymbol{x}) < 0$。所以二者都不是线性泛函。

线性泛函是线性映射，所以也有矩阵表示。选定 V 的基 $\mathcal{B} = (\boldsymbol{b}_1, \dots, \boldsymbol{b}_d)$，输出端取数 1 作基，线性泛函 φ 记录为 $1 \times d$ 矩阵：

$$[\varphi]_{\mathcal{B}} = \big(\varphi(\boldsymbol{b}_1),\ \dots,\ \varphi(\boldsymbol{b}_d)\big)$$

$$\varphi(\boldsymbol{v}) = [\varphi]_{\mathcal{B}}[\boldsymbol{v}]_{\mathcal{B}} = \sum_{j=1}^{d} x_j \varphi(\boldsymbol{b}_j).$$

对象的坐标是一列，读取规则的系数是一行，二者相乘得到读数。

非零泛函的核与像也容易确定。非零泛函取到某个非零值，把相应的输入缩放即可取到任意实数，所以它的像是整个 $\mathbb{R}$；由秩零度定理，它

的核是 $d-1$ 维子空间。读数等于 c 的点组成核的平移 $\boldsymbol{x}_0+\ker\varphi$（其中 $\varphi(\boldsymbol{x}_0)=c$），在平面上就是一族平行直线。

对偶空间　同一个对象可以接受多种读取，两种读取也可以组合。规定

$$(\alpha\varphi+\beta\psi)(\boldsymbol{x})=\alpha\varphi(\boldsymbol{x})+\beta\psi(\boldsymbol{x}),$$

右端对 $\boldsymbol{x}$ 仍保持线性组合，所以线性泛函的线性组合仍是线性泛函。全部线性泛函在这两种运算下构成线性空间，称为 V 的**对偶空间**（dual space），记为 V^*。输入向量是被读取的对象，泛函是读取规则，二者属于不同的空间。即使在 $\mathbb{R}^d$ 中一行系数与一列坐标的数字相同，也不能把二者相加。

对偶基　坐标给出了一组现成的读取，用它们可以确定 V^* 的维数。对 V 的有序基 $\mathcal{B}=(\boldsymbol{b}_1,\dots,\boldsymbol{b}_d)$，第 j 个坐标 $\boldsymbol{v}\mapsto x_j$ 是线性泛函（坐标映射保持线性组合），记为 φ_j。由于 $\boldsymbol{b}_i$ 的坐标是 $\boldsymbol{e}_i$，

$$\varphi_j(\boldsymbol{b}_i)=\delta_{j,i}=\begin{cases}1, & i=j,\\ 0, & i\neq j.\end{cases}\tag{2.23}$$

反过来，线性泛函由它在基向量上的值决定，所以式 (2.23)也可以当作 φ_j 的定义。

这 d 个读取构成 V^* 的一组基。它们张成 V^*：任意 $\varphi\in V^*$ 都能写成

$$\varphi=\sum_{j=1}^{d}\varphi(\boldsymbol{b}_j)\,\varphi_j,$$

因为两边在每个 $\boldsymbol{b}_i$ 上取值都是 $\varphi(\boldsymbol{b}_i)$，而线性泛函由基向量上的值决定。它们线性无关：若 $\sum_j a_j\varphi_j=0$，在 $\boldsymbol{b}_i$ 上取值得 $a_i=0$。

$\varphi_1,\dots,\varphi_d$ 称为 $\mathcal{B}$ 的**对偶基**（dual basis），于是 $\dim V^*=\dim V$。读取 φ 在对偶基下的坐标，正是它在各基向量上的读数 $\varphi(\boldsymbol{b}_j)$，也就是上面那一行系数。

对偶基的每个成员依赖整组基，而不只依赖对应的那个基向量。

示例 2.36　改变第二个基向量会改变第一个坐标读取　比较 $\mathbb{R}^2$ 的标准基 $(\boldsymbol{e}_1,\boldsymbol{e}_2)$ 与基 $(\boldsymbol{e}_1,\boldsymbol{e}_1+\boldsymbol{e}_2)$，两者只有第二个向量不同。标准基的对偶基是两个坐标读取 $\varphi_1(x,y)=x$、$\varphi_2(x,y)=y$。在第二组基下，把 $(x,y)^{\mathsf{T}}$ 重新分解为

$$(x,y)^{\mathsf{T}}=(x-y)\boldsymbol{e}_1+y(\boldsymbol{e}_1+\boldsymbol{e}_2),$$

所以第一个坐标读取变成 $x-y$，第二个坐标读取仍是 y。第一个基向量始终是 $\boldsymbol{e}_1$，相应的对偶读取却从 x 变成了 $x-y$。原因是新的第二个基向量也含有 $\boldsymbol{e}_1$ 分量，第一个读取必须扣除由它贡献的那部分。

对一般的基，对偶基要由方程组 $\varphi_j(\boldsymbol{b}_i)=\delta_{j,i}$ 解出。

示例 2.37　斜基的对偶基　取 $\mathbb{R}^2$ 的基 $\boldsymbol{b}_1=(2,1)^{\mathsf{T}}$、$\boldsymbol{b}_2=(-1,1)^{\mathsf{T}}$，先求它的对偶基。线性泛函都形如 $\varphi_1(x,y)=\alpha x+\beta y$，所以只需定出两个系数。条件 $\varphi_1(\boldsymbol{b}_1)=2\alpha+\beta=1$ 与 $\varphi_1(\boldsymbol{b}_2)=-\alpha+\beta=0$ 给出 $\alpha=\beta=1/3$；同样由 $\varphi_2(\boldsymbol{b}_1)=0$、$\varphi_2(\boldsymbol{b}_2)=1$ 解出 φ_2，得

$$\varphi_1(x,y)=\frac{x+y}{3},\qquad \varphi_2(x,y)=\frac{-x+2y}{3}.$$

再用这组对偶基表示读取横坐标的泛函 $\ell(x,y)=x$。按前面的展开式，系数就是 ℓ 在基向量上的读数 $\ell(\boldsymbol{b}_1)=2$、$\ell(\boldsymbol{b}_2)=-1$，所以 $\ell=2\varphi_1-\varphi_2$。代入验证：$\frac{2}{3}(x+y)-\frac{1}{3}(-x+2y)=x$。可见求读取在对偶基下的坐标不必解方程，只要把它作用在各基向量上。

图 2.11画出这些读取：每个对偶读取只在一个基向量上读到 1，在另一个基向量上读到 0。

换基时，读取系数与坐标按相反的方向变化。设新基 $\mathcal{B}'$ 由换基矩阵 $\boldsymbol{P}=\boldsymbol{S}_{\mathcal{B}\leftarrow\mathcal{B}'}$ 给出，即 $\boldsymbol{b}'_j=\sum_i \boldsymbol{P}_{i,j}\boldsymbol{b}_i$。坐标按

$$[\boldsymbol{v}]_{\mathcal{B}'}=\boldsymbol{P}^{-1}[\boldsymbol{v}]_{\mathcal{B}}$$

变化；读取系数则按 $\varphi(\boldsymbol{b}'_j)=\sum_i \varphi(\boldsymbol{b}_i)\boldsymbol{P}_{i,j}$ 变化，即

$$[\varphi]_{\mathcal{B}'}=[\varphi]_{\mathcal{B}}\boldsymbol{P}.$$

二者相乘时 $\boldsymbol{P}$ 与 $\boldsymbol{P}^{-1}$ 相消，所以读数 $\varphi(\boldsymbol{v})$ 不随基改变，这正是读数应有的性质。

2.4.2 对偶映射

已知线性映射 $T:V\to W$ 和输出端的一个读取 $f\in W^*$，输入 $\boldsymbol{x}$ 经过 T 以后被读成 $f(T\boldsymbol{x})$。先作用、再读取，合起来是输入端的一个读取。由这一复合定义**对偶映射**（dual map）$T':W^*\to V^*$：

$$\begin{aligned} T'f &= f\circ T \\ (T'f)(\boldsymbol{x}) &= f(T\boldsymbol{x}). \end{aligned} \tag{2.24}$$

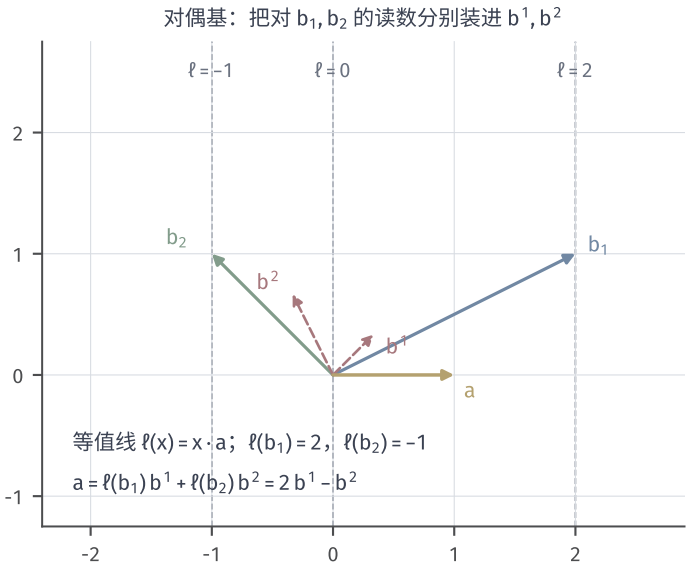


图 2.11　对偶读取的几何示意。蓝箭头 $\boldsymbol{b}_1=(2,1)$、绿箭头 $\boldsymbol{b}_2=(-1,1)$ 为基向量；红色虚线箭头 $\boldsymbol{b}^1=(1/3,1/3)$、$\boldsymbol{b}^2=(-1/3,2/3)$ 分别是对偶基 φ_1,φ_2 的系数向量，即 $\varphi_i(\boldsymbol{x})=\boldsymbol{b}^i\cdot\boldsymbol{x}$，满足 $\varphi_i(\boldsymbol{b}_j)=\delta_{i,j}$。把读取规则画成平面箭头借用了标准内积，这一对应在第 3.6.1节说明。黄色箭头 $\boldsymbol{a}=(1,0)$ 给出读取 $\ell(\boldsymbol{x})=\boldsymbol{a}\cdot\boldsymbol{x}$，灰色虚线为等值线 $\ell=c$（$c=-1,0,2$）；$\ell(\boldsymbol{b}_1)=2$、$\ell(\boldsymbol{b}_2)=-1$，且 $\boldsymbol{a}=2\boldsymbol{b}^1-\boldsymbol{b}^2$。

T' 保持线性组合：$(T'(\alpha f+\beta g))(\boldsymbol{x})=\alpha f(T\boldsymbol{x})+\beta g(T\boldsymbol{x})$。对象从 V 走到 W，读取则从 W^* 传回 V^*，方向相反；这只是把读取规则搬回输入端，不是对 T 求逆。

复合时次序也随之反转：对 $S:W\to U$，$(S\circ T)'f=f\circ S\circ T=T'(S'f)$，即 $(S\circ T)'=T'\circ S'$。

对偶映射的矩阵是转置　设 T 在输入基 $\mathcal{B}=(\boldsymbol{b}_1,\dots,\boldsymbol{b}_d)$、输出基 $\mathcal{C}=(\boldsymbol{c}_1,\dots,\boldsymbol{c}_m)$ 下的矩阵为 $\boldsymbol{A}$，即 $T\boldsymbol{b}_j=\sum_k a_{k,j}\boldsymbol{c}_k$；两组基的对偶基分别记为 $\varphi_1,\dots,\varphi_d$ 与 $\psi_1,\dots,\psi_m$。取输出读取 $f=\sum_i y_i\psi_i$，它传回输入端以后，在输入基向量上的读数是

$$(T'f)(\boldsymbol{b}_j)=f(T\boldsymbol{b}_j)=\sum_i y_i\,\psi_i\Big(\sum_k a_{k,j}\boldsymbol{c}_k\Big)=\sum_i a_{i,j}y_i=(\boldsymbol{A}^{\top}\boldsymbol{y})_j.$$

上一小节说明，读取在对偶基下的坐标就是它在各基向量上的读数，所以 $T'f$ 的坐标为 $\boldsymbol{A}^{\top}\boldsymbol{y}$。也就是说，在对偶基下，对偶映射的矩阵是 $\boldsymbol{A}^{\top}$。转置的乘积规则 $(\boldsymbol{B}\boldsymbol{A})^{\top}=\boldsymbol{A}^{\top}\boldsymbol{B}^{\top}$ 正是 $(S\circ T)'=T'\circ S'$ 的坐标记录。下面用一个具体映射核对这一结论。

示例 2.38 把输出的第一个分量读取传回输入端 再看 $T(x_1,x_2)=(2x_1+x_2,\,3x_2)$，它在标准基下的矩阵为

$$\boldsymbol{A}=\begin{bmatrix}2 & 1\\ 0 & 3\end{bmatrix}.$$

在输出端读取第一个分量，即 $f=\psi_1$，系数 $\boldsymbol{y}=(1,0)^{\top}$。按定义先作用再读取，$(T'f)(\boldsymbol{x})=f(T\boldsymbol{x})=2x_1+x_2$，传回输入端的读取系数为 $(2,1)^{\top}$。按转置计算，$\boldsymbol{A}^{\top}(1,0)^{\top}=(2,1)^{\top}$，两种算法一致。这组系数正是 $\boldsymbol{A}$ 的第一行：输出的第一个分量本来就由第一行与输入相乘得到。

一般地，读取输出的第 i 个分量并传回输入端，得到的读取系数就是 $\boldsymbol{A}$ 的第 i 行，所以 T' 的像在坐标下就是行空间。

再证行秩等于列秩 对偶映射给出定理 2.27的另一个证明，它不把矩阵分解为两个因子，而是计算 T' 的核。$T'f=0$ 意味着 $f(T\boldsymbol{x})=0$ 对一切 $\boldsymbol{x}$ 成立，即 f 在 $\operatorname{im}T$ 上恒为零。所以 $\ker T'$ 由对全部可达输出读数为零的读取组成，在坐标下就是 $\boldsymbol{A}^{\top}\boldsymbol{y}=\boldsymbol{0}$，即左零空间。

下面计算它的维数。设 $r=\operatorname{rank}T$，取 $\operatorname{im}T$ 的基 $\boldsymbol{c}_1,\dots,\boldsymbol{c}_r$ 并扩充为 W 的基 $\boldsymbol{c}_1,\dots,\boldsymbol{c}_m$，对偶基为 $\psi_1,\dots,\psi_m$。读取 $f=\sum_i y_i\psi_i$ 在 $\operatorname{im}T$ 上恒为零，当且仅当它在 $\boldsymbol{c}_1,\dots,\boldsymbol{c}_r$ 上都读到零，即 $y_1=\cdots=y_r=0$。所以 $\ker T'=\operatorname{span}\{\psi_{r+1},\dots,\psi_m\}$，维数为 $m-r$。

对 $T':W^*\to V^*$ 用秩零度定理，$\operatorname{rank}T'=\dim W^*-\dim\ker T'=m-(m-r)=r$。$T'$ 的矩阵是 $\boldsymbol{A}^{\top}$，于是 $\operatorname{rank}\boldsymbol{A}^{\top}=\operatorname{rank}\boldsymbol{A}$。

读取规则至此有了自己的空间、坐标和传递规律。读取的大小，即输入有界时读数最大能有多大，需要先给输入规定范数，由第 3.3.5节的对偶范数回答；读取能否写成与某个固定向量的内积，由第 3.6.1节回答。

2.5 本章小结

本章把对象与记录对象的数分开。线性空间规定哪些对象可以相加和缩放，子空间是其中对线性组合封闭的部分。子空间可以求交、求和；交为零时和是直和，分解唯一。商空间则把相差某个子空间中向量的对象视为相同。

基同时满足张成与线性无关，所以每个向量有唯一的坐标。基的向量个数与选取无关，这个数就是维数；“先取已有的基，再补新方向”给出和空间、补空间与商空间的维数。换基改变坐标，不改变向量，新旧坐标由

可逆的换基矩阵换算。基接近退化时，坐标可能很大，不能用来判断对象的大小。

线性映射保持线性组合。选定两端的基，它记成矩阵，叠加、复合与求逆分别对应矩阵的加法、乘法与求逆。核记录丢失的输入，像记录能到达的输出，秩零度定理说明二者的维数之和等于输入维数；由此可以判断单射、满射与可逆。同一个映射在不同基下的矩阵相差两侧的可逆因子：两端各自换基得到相抵，秩是它的完整不变量；算子两端同时换基得到相似，秩、行列式与迹相同仍不足以保证相似。

对偶空间由线性泛函组成，对偶基就是坐标读取。对偶映射把输出端的读取传回输入端，在对偶基下记录为转置，由此又得到行秩等于列秩。

回到章首的问题：坐标、矩阵和读取系数都是在选定基以后才有的记录，换基时它们按可逆矩阵换算；张成、线性无关、维数、核与像的维数、秩、相似矩阵的行列式与迹，则是对象或映射本身的性质，不随记录方式改变。这些结构还没有规定向量的大小或夹角，所以近共线基下的大坐标究竟意味着什么，还无法定量回答。第 3章引入范数和内积，讨论收敛、正交分解与最佳近似。

第 3 章

赋范空间与内积空间

上一章的线性空间只有加法和数乘。借助它们可以判断一个向量能否由给定向量线性表示、表示是否唯一，却无法回答两个向量相差多少、一列近似是否趋于某个极限、两个方向是否垂直。本章给线性空间补上这两类度量结构：先用范数规定大小，再用内积规定角度。

本章分两步补上这些结构。前三节只用范数。第 3.1节给出范数的公理与例子，并用显式不等式比较常用的坐标范数，说明误差的数值依赖所选范数。第 3.2节用范数定义向量列与矩阵列的收敛、映射的联合极限与连续性，并证明闭有界集上的连续函数取到最值、一致连续。

第 3.3节利用上一节的最值定理证明：有限维空间中任意两个范数等价，空间完备，绝对收敛的向量与矩阵级数收敛。在此基础上，矩阵范数衡量线性映射的最大放大倍数，对偶范数衡量误差受限时线性读取的最大变化，商范数衡量忽略一个子空间后剩下的大小。第 8章的矩阵幂与 Neumann 级数、第 11章的迭代以及第 17章的微分，都使用这套分析基础。

范数不给出角度，一般范数下向子空间的最近点也可能不唯一。后三节引入内积来回答这些问题。第 3.4节从公理推出长度、夹角和 Cauchy–Schwarz 不等式，并用 Gram 矩阵记录一组向量的两两内积。第 3.5节研究正交分解、标准正交基和正交投影，证明正交投影是子空间中唯一的最近点。第 3.6节用内积把上一章的线性泛函表示为与固定向量的内积，并把对偶映射改写成内积空间之间的伴随。

本章依赖前两章的线性运算、基与坐标，以及一元分析中的数列极限、确界和最值定理（第 3.2节开头说明所用的结论）。全章只讨论有限维空间；收敛与连续性适用于一般映射，不限于线性映射。无限维的函数空间中，范数等价、完备性和最近点存在都可能失败，那里的理论可参考卷四第 6 章“函数空间”。

3.1　范数与距离

用多项式近似一个函数时，要估计误差有多大；迭代产生一列近似时，要判断它是否趋于某个对象。这些问题都需要先规定向量的大小。第 1章用 ℓ_1、ℓ_2、ℓ_∞ 范数度量 $\mathbb{R}^d$ 中数组的大小，本节把这种度量推广到一般线性空间。

本节先给出范数的公理和例子，再用显式不等式比较常用的坐标范数。这里只用到线性运算与标量不等式。下一节用范数定义收敛、映射的极限与连续性；第 3.3节再证明有限维空间中任意两个范数等价、空间完备，并讨论矩阵、线性泛函和商空间的大小。本章只讨论有限维空间。

3.1.1　范数的定义与示例

范数的定义　第 1章的 ℓ_1、ℓ_2、ℓ_∞ 范数算法不同，却有几条共同性质。大小非负，只有零向量的大小为零。向量放大 c 倍时，大小变为原来的 $|c|$ 倍。两个向量之和的大小不超过各自大小之和。这些性质只涉及加法和数乘，因此可以直接作为一般线性空间上“大小”的要求。

定义 3.1　赋范空间　设 V 是实线性空间。映射 $\|\cdot\| : V \to [0,\infty)$ 若对任意 $\boldsymbol{x},\boldsymbol{y} \in V$ 与 $c \in \mathbb{R}$ 满足

1. 正定性：$\|\boldsymbol{x}\| = 0$ 当且仅当 $\boldsymbol{x} = \boldsymbol{0}$；
2. 齐次性：$\|c\boldsymbol{x}\| = |c|\,\|\boldsymbol{x}\|$；
3. 三角不等式：$\|\boldsymbol{x}+\boldsymbol{y}\| \le \|\boldsymbol{x}\| + \|\boldsymbol{y}\|$，

就称为 V 上的**范数**（norm）；配备范数的线性空间 $(V,\|\cdot\|)$ 称为**赋范空间**（normed space）。

范数诱导距离 $d(\boldsymbol{x},\boldsymbol{y}) = \|\boldsymbol{x}-\boldsymbol{y}\|$。这个距离非负，只在 $\boldsymbol{x}=\boldsymbol{y}$ 时为零，对称，并满足 $d(\boldsymbol{x},\boldsymbol{z}) \le d(\boldsymbol{x},\boldsymbol{y}) + d(\boldsymbol{y},\boldsymbol{z})$。这四条正是度量空间对距离的要求，所以赋范空间是一类特殊的度量空间；一般度量空间可参考卷四第 1 章“度量空间”。它的距离还与线性运算相容：平移不改变距离，缩放按同一比例改变距离。

三角不等式还能反过来控制长度之差。把它用于 $\boldsymbol{x} = (\boldsymbol{x}-\boldsymbol{y}) + \boldsymbol{y}$，得 $\|\boldsymbol{x}\| - \|\boldsymbol{y}\| \le \|\boldsymbol{x}-\boldsymbol{y}\|$；交换 $\boldsymbol{x},\boldsymbol{y}$，又得 $\|\boldsymbol{y}\| - \|\boldsymbol{x}\| \le \|\boldsymbol{x}-\boldsymbol{y}\|$。两式合起来就是反向三角不等式

$$\bigl|\,\|\boldsymbol{x}\| - \|\boldsymbol{y}\|\,\bigr| \le \|\boldsymbol{x}-\boldsymbol{y}\|. \tag{3.1}$$

即两个向量的长度之差不超过差向量的长度。下一节用它说明范数随向量收敛。

坐标范数的公理检验 现在检验第 1.1.2节的 p 范数确实是范数。非负性、正定性与齐次性可以从公式直接读出，需要证明的只有三角不等式。$p=1$ 和 $p=\infty$ 时，它由实数的三角不等式逐坐标得到，细节见下面 Minkowski 不等式的证明。$1<p<\infty$ 时，需要先建立 Hölder 不等式。

Hölder 不等式 Hölder 不等式用一对 p 范数与 q 范数控制两个向量逐坐标乘积之和。两个指数须满足共轭条件 $1/p+1/q=1$。

定理 3.2 有限维 Hölder 不等式 设 $1\le p,q\le\infty$ 且 $1/p+1/q=1$（约定 $1/\infty=0$），则 $|\boldsymbol{x}^{\top}\boldsymbol{y}|\le\|\boldsymbol{x}\|_p\|\boldsymbol{y}\|_q$。

证明 先设 $1<p,q<\infty$，分三步证明。

第一步，证明 Young 不等式：对 $u,v\ge 0$，

$$uv\le\frac{u^p}{p}+\frac{v^q}{q}.$$

$u=0$ 时左侧为零，不等式成立。$u>0$ 时令 $t=v/u^{p-1}\ge 0$。由 $1/p+1/q=1$ 得 $(p-1)q=p$，于是 $v^q=t^q u^p$、$uv=tu^p$，不等式化为

$$u^p\Big(\frac{1}{p}+\frac{t^q}{q}-t\Big)\ge 0.$$

函数 $f(t)=1/p+t^q/q-t$ 的导数 $t^{q-1}-1$ 在 $0<t<1$ 时为负、在 $t>1$ 时为正，所以 f 在 $t\ge 0$ 上的最小值是 $f(1)=1/p+1/q-1=0$，不等式成立。

第二步，在单位尺度下求和。若 $\boldsymbol{x}$ 或 $\boldsymbol{y}$ 为零向量，结论两侧都为零。否则令 $u_j=|x_j|/\|\boldsymbol{x}\|_p$、$v_j=|y_j|/\|\boldsymbol{y}\|_q$，则 $\sum_j u_j^p=\sum_j v_j^q=1$。对每个 j 用 Young 不等式再求和，得

$$\sum_j u_j v_j\le\frac{1}{p}\sum_j u_j^p+\frac{1}{q}\sum_j v_j^q=\frac{1}{p}+\frac{1}{q}=1.$$

第三步，恢复尺度。上式两边乘以 $\|\boldsymbol{x}\|_p\|\boldsymbol{y}\|_q$，再用 $|\boldsymbol{x}^{\top}\boldsymbol{y}|\le\sum_j|x_j||y_j|$，即得

$$|\boldsymbol{x}^{\top}\boldsymbol{y}|\le\sum_j|x_j||y_j|\le\|\boldsymbol{x}\|_p\|\boldsymbol{y}\|_q.$$

端点情形直接估计。$p=1$、$q=\infty$ 时，

$$\sum_j |x_j||y_j| \le \Big(\max_j |y_j|\Big)\sum_j |x_j| = \|\boldsymbol{x}\|_1\|\boldsymbol{y}\|_\infty;$$

$p=\infty$、$q=1$ 时交换两个向量的角色。 ■

$p=q=2$ 时，它给出 $|\boldsymbol{x}^{\top}\boldsymbol{y}| \le \|\boldsymbol{x}\|_2\|\boldsymbol{y}\|_2$。第 3.4.1节将只用内积公理，对任一内积证明同样形式的不等式，即 Cauchy–Schwarz 不等式。

Minkowski 不等式　有了 Hölder 不等式，就可以对一般的 p 证明三角不等式。做法是把 $|x_j+y_j|^p$ 拆成两个乘积之和，再对每一部分使用 Hölder 不等式。

定理 3.3　有限维 Minkowski 不等式　设 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^d$，$1\le p\le\infty$，则

$$\|\boldsymbol{x}+\boldsymbol{y}\|_p \le \|\boldsymbol{x}\|_p + \|\boldsymbol{y}\|_p.$$

证明　先处理两个端点。$p=1$ 时，对每个坐标使用实数的三角不等式，再求和，得到

$$\sum_j |x_j+y_j| \le \sum_j |x_j| + \sum_j |y_j|.$$

$p=\infty$ 时，对每个 j 都有

$$|x_j+y_j| \le \|\boldsymbol{x}\|_\infty + \|\boldsymbol{y}\|_\infty.$$

左侧对 j 取最大值，就得到所需结论。

下面设 $1<p<\infty$。若 $\boldsymbol{x}+\boldsymbol{y}=\boldsymbol{0}$，左侧为零，结论成立；以下设和向量非零。取 $q=p/(p-1)$，则 $1/p+1/q=1$。对每个坐标有

$$\begin{aligned} |x_j+y_j|^p &= |x_j+y_j|^{p-1}|x_j+y_j| \\ &\le |x_j+y_j|^{p-1}(|x_j|+|y_j|). \end{aligned}$$

令 $s_j=|x_j+y_j|^{p-1}$，把这些数排成向量 $\boldsymbol{s}$。由于 $(p-1)q=p$，它的 q 范数为

$$\begin{aligned} \|\boldsymbol{s}\|_q &= \Big(\sum_j |x_j+y_j|^p\Big)^{1/q} \\ &= \|\boldsymbol{x}+\boldsymbol{y}\|_p^{p-1}. \end{aligned}$$

把逐坐标的不等式求和，并对含 $|x_j|$ 和含 $|y_j|$ 的两部分分别使用 Hölder 不等式，得到

$$\begin{aligned}\|\boldsymbol{x}+\boldsymbol{y}\|_p^p &\le \sum_j s_j|x_j| + \sum_j s_j|y_j| \\ &\le \|\boldsymbol{s}\|_q\big(\|\boldsymbol{x}\|_p + \|\boldsymbol{y}\|_p\big) \\ &= \|\boldsymbol{x}+\boldsymbol{y}\|_p^{p-1}\big(\|\boldsymbol{x}\|_p + \|\boldsymbol{y}\|_p\big).\end{aligned}$$

两边除以正数 $\|\boldsymbol{x}+\boldsymbol{y}\|_p^{p-1}$，即得结论。 ■

结合前面直接读出的三条性质，每个 p 范数都满足定义 3.1。特别地，欧氏长度满足三角不等式。

其他空间上的范数 除 p 范数外，前面还出现过别的范数。同形矩阵上的 Frobenius 范数，就是把矩阵元素排成向量后的 2 范数；诱导矩阵范数将在第 3.3.4节定义并验证。

在一般线性空间上，最直接的做法是借助坐标。若 $\|\cdot\|_\star$ 是 $\mathbb{R}^d$ 上的范数，$\mathcal{B}$ 是 V 的基，则 $\|\boldsymbol{v}\| = \|[\boldsymbol{v}]_{\mathcal{B}}\|_\star$ 是 V 上的范数，因为坐标映射是保持线性组合的双射。也可以不经过坐标，直接用对象本身的性质规定范数。下面在 P_k 上各举一例。

示例 3.4　多项式空间上的两个范数 对 $p = a_0 + a_1 t + \cdots + a_k t^k$，可以看系数，也可以看函数在区间 $[0,1]$ 上的取值，由此得到两个规则：

$$p \mapsto \max_{0\le j\le k} |a_j|,$$

$$p \mapsto \|p\|_\infty = \max_{t\in[0,1]} |p(t)|.$$

第一个规则正是坐标 $(a_0,\dots,a_k)$ 在基 $(1,t,\dots,t^k)$ 下的 ℓ_∞ 范数，按上面借助坐标的方法，它是范数。第二个规则不经过坐标，需要逐条检验公理。齐次性在每个 t 处成立，取最大值后仍成立。对三角不等式，每个 t 都满足 $|p(t)+q(t)| \le |p(t)| + |q(t)| \le \|p\|_\infty + \|q\|_\infty$，左侧再对 t 取最大值即可。正定性依赖多项式的代数性质：次数不超过 k 的非零多项式至多有 k 个根，不能在整个区间 $[0,1]$ 上为零。

所以两个规则都是 P_k 上的范数。前者借助坐标，后者直接用函数值，检验时只需用到多项式本身的性质。

有时只关心向量的一部分信息。这时可以去掉正定性，只保留非负性、齐次性与三角不等式，得到的尺度称为**半范数**（seminorm）。半范数可能把两个不同的点判为距离为零。

示例 3.5　只看第一个坐标的半范数　在 $\mathbb{R}^2$ 上只用第一个坐标衡量大小，令 $p(\boldsymbol{x}) = |x_1|$。半范数要求的三条性质都由实数绝对值的性质得到：$p(\boldsymbol{x}) \geq 0$，$p(c\boldsymbol{x}) = |cx_1| = |c|\,p(\boldsymbol{x})$，并且 $p(\boldsymbol{x}+\boldsymbol{y}) = |x_1+y_1| \leq |x_1| + |y_1| = p(\boldsymbol{x}) + p(\boldsymbol{y})$。缺少的是正定性：非零向量 $(0,1)^{\mathsf{T}}$ 满足 $p\big((0,1)^{\mathsf{T}}\big) = 0$。

因此 p 是半范数而不是范数。用它度量距离时，$(0,0)^{\mathsf{T}}$ 与 $(0,1)^{\mathsf{T}}$ 的距离为 $p\big((0,-1)^{\mathsf{T}}\big) = 0$，两个不同的点被视为没有差别，第二个坐标上的差别完全被忽略。

因此使用半范数之前，须先说明哪些差别被有意忽略。

3.1.2　常用坐标范数的比较

不同的 p 范数给同一个向量的大小不同。误差估计常常要在两种范数之间换算，因此需要知道它们最多相差多少倍。对 $\mathbb{R}^d$ 中的坐标范数，这个倍数可以由有限求和直接算出。

定理 3.6　坐标范数的比较　设 $1 \leq p \leq q \leq \infty$，约定 $1/\infty = 0$。对 $\boldsymbol{x} \in \mathbb{R}^d$，

$$\|\boldsymbol{x}\|_q \leq \|\boldsymbol{x}\|_p \leq d^{1/p-1/q}\|\boldsymbol{x}\|_q.$$

证明　$\boldsymbol{x} = \boldsymbol{0}$ 时三项都为零，下设 $\boldsymbol{x} \neq \boldsymbol{0}$。

左侧。令 $\boldsymbol{u} = \boldsymbol{x}/\|\boldsymbol{x}\|_p$，则 $\|\boldsymbol{u}\|_p = 1$，所以每个 $|u_j| \leq 1$。$q = \infty$ 时这就是 $\|\boldsymbol{u}\|_\infty \leq 1$。$q < \infty$ 时，由 $|u_j| \leq 1$ 与 $q \geq p$ 得 $|u_j|^q \leq |u_j|^p$，求和得 $\|\boldsymbol{u}\|_q^q \leq \|\boldsymbol{u}\|_p^p = 1$。两种情形都有 $\|\boldsymbol{u}\|_q \leq 1$，两边乘以 $\|\boldsymbol{x}\|_p$ 即得。

右侧。$p = q$ 时显然。$q = \infty$ 时，$\sum_j |x_j|^p \leq d\,\|\boldsymbol{x}\|_\infty^p$，开 p 次方即得。设 $p < q < \infty$，取 $r = q/p > 1$，其共轭指数满足 $1/r' = 1 - p/q$。对向量 $(|x_1|^p, \dots, |x_d|^p)^{\mathsf{T}}$ 与全 1 向量使用 Hölder 不等式（定理 3.2），

$$\sum_j |x_j|^p \cdot 1 \leq \Big(\sum_j |x_j|^q\Big)^{p/q} d^{\,1-p/q} = \|\boldsymbol{x}\|_q^p\, d^{\,1-p/q}.$$

开 p 次方，得 $\|\boldsymbol{x}\|_p \leq d^{1/p-1/q}\|\boldsymbol{x}\|_q$。 ∎

最常用的是 $p, q \in \{1, 2, \infty\}$ 的情形：

$$\|\boldsymbol{x}\|_\infty \le \|\boldsymbol{x}\|_2 \le \sqrt{d}\,\|\boldsymbol{x}\|_\infty,$$
$$\|\boldsymbol{x}\|_2 \le \|\boldsymbol{x}\|_1 \le \sqrt{d}\,\|\boldsymbol{x}\|_2,$$
$$\|\boldsymbol{x}\|_\infty \le \|\boldsymbol{x}\|_1 \le d\,\|\boldsymbol{x}\|_\infty.$$

下面在示例 1.6的向量上核对前两行。

示例 3.7　范数比较的数值核对　取 $d = 2$ 与 $\boldsymbol{x} = (3, -4)^{\top}$。示例 1.6已经算出 $\|\boldsymbol{x}\|_1 = 7$，$\|\boldsymbol{x}\|_2 = 5$，$\|\boldsymbol{x}\|_\infty = 4$。代入前两行，比较常数分别为 $\sqrt{2}$：

$$4 \le 5 \le 4\sqrt{2} \approx 5.66,$$
$$5 \le 7 \le 5\sqrt{2} \approx 7.07.$$

四个不等式都成立，而且右侧的界离实际值不远。同一个误差 $\boldsymbol{x}$ 在三种范数下读出 4、5、7 三个不同的数，比较定理保证的是这些读数之间的倍数不超过与维数有关的常数。

两侧的常数一般都不能改进，取等号的向量很简单。

示例 3.8　比较常数的取等　两个极端的向量分别使两侧取等号：只有一个非零坐标的 $\boldsymbol{e}_1$，和各坐标一样大的全 1 向量 $\mathbf{1}$。对每个 p 都有 $\|\boldsymbol{e}_1\|_p = 1$，所以 $\boldsymbol{e}_1$ 使左侧取等号。另一方面，$p < \infty$ 时 $\|\mathbf{1}\|_p = d^{1/p}$，又 $\|\mathbf{1}\|_\infty = 1$，因此在约定 $1/\infty = 0$ 下总有 $\|\mathbf{1}\|_p = d^{1/p - 1/q}\|\mathbf{1}\|_q$，右侧取等号。

大小全部集中在一个坐标上时，各范数读数相同；各坐标绝对值相等时，读数相差最大。例如 ℓ_1 与 ℓ_∞ 之间的常数 1 与 d 分别由 $\boldsymbol{e}_1$ 和 $\mathbf{1}$ 达到，都不能改进。

右侧的常数随维数增长。维数较大时，换用范数带来的倍数差别不能在误差估计中忽略；固定维数下的比较式也不能当作对所有维数一致成立的界。这里只比较了有明确公式的坐标范数。有限维空间上任意两个范数都只相差常数倍（定理 3.27），这一结论的证明要用到闭有界集上连续函数的最值，在第 3.3.1节给出。

3.2 收敛、极限与连续性

上一节的范数度量一个向量的大小。本节用它描述“接近”：一列向量或矩阵怎样趋于极限，映射的输出怎样随输入的接近而接近。向量与矩阵的分量都只有有限个，许多结论可以逐个坐标归结为一元的结果：数列极限的运算法则、闭区间上的 Bolzano–Weierstrass 定理与最值定理、一致连续

性，以及实数列的柯西收敛准则。这些一元结论及其证明可参考卷一第 5 章“极限与连续”，本章用到时只说明所用的结论和条件。

本节先固定欧氏范数和 Frobenius 范数，建立逐坐标判据、映射的极限与连续性，以及闭有界集上连续函数的基本性质。换用任意范数时这些性质是否保留，留到下一节证明，以免在范数等价的证明中循环使用结论。这些概念适用于一般映射，不限于线性映射；后面的矩阵幂、迭代和多元微分都以它们为基础。

3.2.1　向量列与矩阵列的收敛

一元数列 $a_k \to a$ 的意思是误差 $|a_k - a|$ 趋于零。向量有多个坐标，要求的是整个误差向量的大小趋于零。在 $\mathbb{R}^d$ 中用欧氏范数度量这个大小，在 $\mathbb{R}^{m\times n}$ 中用 Frobenius 范数。

定义 3.9　向量列与矩阵列的收敛　设 $\boldsymbol{x}_k, \boldsymbol{x} \in \mathbb{R}^d$。若实数列 $\|\boldsymbol{x}_k - \boldsymbol{x}\|_2 \to 0$，就称向量列 $(\boldsymbol{x}_k)$ 收敛到 $\boldsymbol{x}$，记为 $\boldsymbol{x}_k \to \boldsymbol{x}$。同样，同形矩阵列 $\boldsymbol{A}_k$ 与矩阵 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 满足 $\|\boldsymbol{A}_k - \boldsymbol{A}\|_{\mathrm{F}} \to 0$ 时，称 $\boldsymbol{A}_k \to \boldsymbol{A}$。

序列中各项的维数或形状都相同，候选极限也属于同一个空间。复向量与复矩阵可以把每个元素拆成实部和虚部，看作维数加倍的实向量，作同样的讨论。

逐坐标判据　欧氏误差与各坐标误差之间有显式的夹逼关系，所以向量收敛可以逐个坐标检查。

定理 3.10　收敛等价于逐坐标收敛　$\boldsymbol{x}_k \to \boldsymbol{x}$ 当且仅当每个坐标 $x_{k,j} \to x_j$ $(j = 1, \dots, d)$；$\boldsymbol{A}_k \to \boldsymbol{A}$ 当且仅当每个元素 $(\boldsymbol{A}_k)_{i,j} \to a_{i,j}$。

证明　由定理 3.6，

$$\max_j |x_{k,j} - x_j| \le \|\boldsymbol{x}_k - \boldsymbol{x}\|_2 \le \sqrt{d}\, \max_j |x_{k,j} - x_j|.$$

左侧不等式说明，欧氏误差趋于零时，每个坐标误差都趋于零。反过来，设每个坐标误差都趋于零。给定 $\varepsilon > 0$，对每个 j 取 N_j，使 $k > N_j$ 时 $|x_{k,j} - x_j| < \varepsilon$；令 $N = \max_j N_j$，则 $k > N$ 时 $\max_j |x_{k,j} - x_j| < \varepsilon$，由右侧不等式，欧氏误差小于 $\sqrt{d}\,\varepsilon$。把矩阵的元素按固定顺序排成向量，Frobenius 范数就是欧氏范数，矩阵的结论随之得到。　∎

证明中取 $N = \max_j N_j$ 要求坐标只有有限个。换用别的范数或别的基是否改变结论，在第 3.3.1节回答。

极限的唯一性与运算 极限若存在则唯一：若 $\boldsymbol{x}_k \to \boldsymbol{x}$ 且 $\boldsymbol{x}_k \to \boldsymbol{y}$，则

$$\|\boldsymbol{x}-\boldsymbol{y}\|_2 \le \|\boldsymbol{x}-\boldsymbol{x}_k\|_2 + \|\boldsymbol{x}_k-\boldsymbol{y}\|_2 \to 0.$$

由反向三角不等式 (3.1)，$\boldsymbol{x}_k \to \boldsymbol{x}$ 时还有 $\|\boldsymbol{x}_k\|_2 \to \|\boldsymbol{x}\|_2$。收敛序列有界：取 N 使 $k > N$ 时 $\|\boldsymbol{x}_k - \boldsymbol{x}\|_2 < 1$，则所有项的长度不超过 $\max\{\|\boldsymbol{x}_1\|_2, \dots, \|\boldsymbol{x}_N\|_2, \|\boldsymbol{x}\|_2 + 1\}$。

线性运算和乘法都保持极限。设 $\boldsymbol{x}_k \to \boldsymbol{x}$、$\boldsymbol{y}_k \to \boldsymbol{y}$，实数列 $c_k \to c$，则

$$\boldsymbol{x}_k + \boldsymbol{y}_k \to \boldsymbol{x}+\boldsymbol{y}, \qquad c_k\boldsymbol{x}_k \to c\boldsymbol{x}, \qquad \boldsymbol{x}_k^{\top}\boldsymbol{y}_k \to \boldsymbol{x}^{\top}\boldsymbol{y};$$

若矩阵列 $\boldsymbol{A}_k \to \boldsymbol{A}$、$\boldsymbol{B}_k \to \boldsymbol{B}$ 且形状相容，则 $\boldsymbol{A}_k\boldsymbol{B}_k \to \boldsymbol{A}\boldsymbol{B}$。理由相同：结果的每个坐标或元素都是有限个标量数列的和与积，由一元数列的运算法则逐个得到极限，再用逐坐标判据。

3.2.2 开集、闭集与有界集

讨论映射的极限与连续性时，先要说明输入在什么样的集合里变化：基点周围是否留有向各个方向移动的余地，集合是否包含它边界上的点，集合是否伸向无穷远。这三个问题分别由开集、闭集与有界集回答。本小节在 $\mathbb{R}^d$ 中用欧氏距离叙述，矩阵空间按 Frobenius 范数同样定义。

开球与开集 以 $\boldsymbol{a}$ 为心、半径为 $r > 0$ 的开球是

$$B(\boldsymbol{a}, r) = \{\boldsymbol{x} : \|\boldsymbol{x}-\boldsymbol{a}\|_2 < r\},$$

即与 $\boldsymbol{a}$ 的距离小于 r 的全部点。$d = 1$ 时它是开区间 $(a-r, a+r)$，$d = 2$ 时是不含边界圆的圆盘。含有某个开球 $B(\boldsymbol{a}, r)$ 的集合称为 $\boldsymbol{a}$ 的一个邻域；说“$\boldsymbol{a}$ 附近”某性质成立，就是指它在 $\boldsymbol{a}$ 的某个邻域内成立。

> **定义 3.11 开集、闭集与有界集** 设 $K \subseteq \mathbb{R}^d$。
>
> 1. 若 K 中每一点 $\boldsymbol{a}$ 都有某个开球 $B(\boldsymbol{a}, r) \subseteq K$，就称 K 为开集。
> 2. 若补集 $\mathbb{R}^d \setminus K$ 是开集，就称 K 为闭集。
> 3. 若存在 R，使 $\|\boldsymbol{x}\|_2 \le R$ 对一切 $\boldsymbol{x} \in K$ 成立，就称 K 有界。

开集中的每一点都被同一集合的点包围：从这一点出发，向任何方向走足够小的一步都还在集合里。后面在开集上求导数，正是要用到这一点，因为双侧差商需要向两侧都能移动。半径 r 可以随点改变，越靠近边界，能取的半径越小。

闭集与开集不是对立的两类。整个空间 $\mathbb{R}^d$ 与空集既开又闭；平面上的半开带 $\{(x, y) : 0 \le x < 1\}$ 既不开也不闭，因为它含有边界 $x = 0$ 上的点，

却不含边界 $x=1$ 上的点。闭集的直观意义是“包含自己的全部边界点”，下面的序列判据把这一点说清楚。

有界性只说明集合不伸向无穷远。它与中心的选取无关：若 $K\subseteq B(\boldsymbol{a},r)$，则由三角不等式，$K$ 中的点满足 $\|\boldsymbol{x}\|_2\le\|\boldsymbol{a}\|_2+r$。

聚点、孤立点与边界点　若以 $\boldsymbol{a}$ 为心的每个开球都含有 D 中不同于 $\boldsymbol{a}$ 的点，就称 $\boldsymbol{a}$ 是 D 的聚点。聚点可以不属于 D；它的意义在于，D 中的点能从 $\boldsymbol{a}$ 以外任意接近 $\boldsymbol{a}$，因此可以讨论 $\boldsymbol{x}\to\boldsymbol{a}$ 时的极限。D 中不是聚点的点称为孤立点：它周围某个小球内只有它自己属于 D。

若以 $\boldsymbol{a}$ 为心的每个开球既含 K 中的点、又含补集中的点，就称 $\boldsymbol{a}$ 是 K 的边界点。例如开圆盘的边界点就是单位圆上的点，它们都不属于开圆盘，却都是开圆盘的聚点。

闭集的序列判据　与实轴上的闭集一样，$\mathbb{R}^d$ 中的闭集也可以用序列刻画：闭集包含其中任何收敛序列的极限。

引理 3.12　闭集的序列判据　$K\subseteq\mathbb{R}^d$ 是闭集，当且仅当：K 中任何收敛序列的极限仍属于 K。

证明　设 K 闭，$\boldsymbol{x}_k\in K$，$\boldsymbol{x}_k\to\boldsymbol{x}$。若 $\boldsymbol{x}\notin K$，补集是开集，存在开球 $B(\boldsymbol{x},r)$ 与 K 不相交；而 k 充分大时 $\boldsymbol{x}_k\in B(\boldsymbol{x},r)$，矛盾。反过来，设 K 包含其中收敛序列的极限。若补集不是开集，就有 $\boldsymbol{x}\notin K$，使每个 $B(\boldsymbol{x},1/k)$ 都含有 K 中的点 $\boldsymbol{x}_k$；于是 $\boldsymbol{x}_k\to\boldsymbol{x}$，$\boldsymbol{x}$ 应属于 K，矛盾。 ∎

示例 3.13　圆盘与矩阵球　比较平面上的开圆盘 $\{x^2+y^2<1\}$ 与闭圆盘 $\{x^2+y^2\le1\}$，再看矩阵空间中的球 $\{\boldsymbol{X}\in\mathbb{R}^{2\times2}:\|\boldsymbol{X}-\boldsymbol{I}_2\|_{\mathrm F}\le1/2\}$，就能看到三个定义怎样分别检验。

开圆盘中的点 $\boldsymbol{x}$ 满足 $\|\boldsymbol{x}\|_2<1$。取 $r=1-\|\boldsymbol{x}\|_2$，由三角不等式，$B(\boldsymbol{x},r)$ 含于开圆盘，所以开圆盘是开集。它却不是闭集：序列 $(1-1/k,0)$ 留在开圆盘中，极限 $(1,0)$ 却不属于它；同样，边界圆上的点都是开圆盘的聚点。闭圆盘的情形相反。若闭圆盘中的序列 $\boldsymbol{x}_k\to\boldsymbol{x}$，由 $\|\boldsymbol{x}_k\|_2\le1$ 与范数的收敛得 $\|\boldsymbol{x}\|_2\le1$，再由序列判据知闭圆盘是闭集。矩阵球按同样的论证是闭集，它又含于以零矩阵为心、半径 $\|\boldsymbol{I}_2\|_{\mathrm F}+1/2$ 的球内，因而有界。

所以开圆盘开而不闭，闭圆盘与矩阵球闭且有界。开圆盘缺少的边界点仍是它的聚点，因此函数的定义域是开圆盘时，也可以在这些不属于定义域的点处讨论极限。

开圆盘缺少的恰好是它的边界圆。一般地，把 K 中序列所有可能的极限都补进来，得到 K 的闭包

$$\overline{K} = \{\boldsymbol{x} \in \mathbb{R}^d : \text{存在} \boldsymbol{x}_k \in K \text{使} \boldsymbol{x}_k \to \boldsymbol{x}\}.$$

取常数序列可知 $K \subseteq \overline{K}$；$\overline{K}$ 中多出的点都是 K 的聚点，所以 $\overline{K}$ 就是 K 与它全部聚点的并。闭包本身是闭集：若 $\boldsymbol{y}_k \in \overline{K}$ 且 $\boldsymbol{y}_k \to \boldsymbol{y}$，对每个 k 取 $\boldsymbol{x}_k \in K$ 使 $\|\boldsymbol{x}_k - \boldsymbol{y}_k\|_2 < 1/k$，则 $\boldsymbol{x}_k \to \boldsymbol{y}$，于是 $\boldsymbol{y} \in \overline{K}$，再用序列判据。另一方面，任何包含 K 的闭集都含有 K 中序列的极限，因而含有 $\overline{K}$。所以闭包是包含 K 的最小闭集，K 闭当且仅当 $\overline{K} = K$。例如开圆盘的闭包是闭圆盘。

三种说法从不同角度描述同一件事：邻域描述一点周围的情形，边界点同时贴近集合与补集，闭包则是把边界上缺少的点补齐以后的集合。

3.2.3 映射的联合极限

本小节与下一小节研究映射 $F : D \to W$，其中 $D \subseteq V$。V 与 W 取 $\mathbb{R}^d$ 或矩阵空间，分别配欧氏范数或 Frobenius 范数；记号 $\|\cdot\|$ 按所在空间理解。输出为实数（$W = \mathbb{R}$）时，F 是多元标量函数；输出为向量时是向量值映射；输入为矩阵时，例如 $\boldsymbol{X} \mapsto \boldsymbol{X}^{-1}$，就是矩阵的函数。下面的许多例子取标量输出，因为困难都来自输入的多个坐标。

多元标量函数 多元标量函数在每个输入点给出一个实数。$d = 2$ 时这类函数最容易画出来：把 $f(x, y)$ 当作水平位置 (x, y) 上方的高度，所有点 $(x, y, f(x, y))$ 组成一张曲面，称为函数的图像。

定义 3.14 多元标量函数 设 d 为正整数、$D \subseteq \mathbb{R}^d$。映射 $f : D \to \mathbb{R}$ 称为多元标量函数；它把整个输入点 $\boldsymbol{x} = (x_1, \dots, x_d)^{\top}$ 映为一个实数 $f(\boldsymbol{x})$。

例如 $f(x, y) = x^2 + xy + y^2$ 在 $(1, 2)$ 处取值 $1 + 2 + 4 = 7$。观察这类函数常用两种办法。第一种是切片：固定 $y = 2$，得到一元函数 $x \mapsto x^2 + 2x + 4$。几何上，这是用竖直平面 $y = 2$ 去截曲面，截出一条曲线；它只反映原函数在一条直线上的取值。第二种是等值曲线：把函数值相同的点连起来。例如 $x^2 + xy + y^2 = 7$ 是平面上一个经过 $(1, 2)$ 的倾斜椭圆，就像地图上的等高线。

后文的偏导数就是切片曲线的斜率，梯度则与等值曲线的方向有关。但切片只看一条直线。极限与连续性要回答的是：在整个平面中趋近基点时，函数值怎样变化。

3.2.3.1 极限的定义

一元时，$x \to a$ 只能从左右两侧靠近；在平面中，输入可以沿直线、抛物线、螺旋线等路径趋近基点。极限的定义必须用一个条件同时控制所有这些输入，不能按路径分别选择误差范围。做法是只看输入到基点的距离。

一元极限中，条件 $0 < |x - a| < \delta$ 表示 x 落在 a 两侧、半径为 δ 的小区间内且不等于 a。在平面上，与之对应的是以 $\boldsymbol{a}$ 为圆心、半径为 δ 的圆盘去掉圆心；在 $\mathbb{R}^d$ 中则是去心的球。

欧氏距离 $\|\boldsymbol{x} - \boldsymbol{a}\|_2$ 同时控制各坐标的偏移，用它代替 $|x - a|$，就得到多元极限的邻域条件；输出的误差用输出空间的范数度量。设 $F : D \to W$，$\boldsymbol{a}$ 是 D 的聚点。这个条件保证 $\boldsymbol{x}$ 确实能在定义域内趋近 $\boldsymbol{a}$。

定义 3.15　映射的极限　若对每个 $\varepsilon > 0$，都存在 $\delta > 0$，使得

$$\boldsymbol{x} \in D, \quad 0 < \|\boldsymbol{x} - \boldsymbol{a}\| < \delta \quad \Longrightarrow \quad \|F(\boldsymbol{x}) - \boldsymbol{L}\| < \varepsilon,$$

则称 F 在 $\boldsymbol{x} \to \boldsymbol{a}$ 时的极限为 $\boldsymbol{L}$，记为 $\lim_{\boldsymbol{x} \to \boldsymbol{a}} F(\boldsymbol{x}) = \boldsymbol{L}$。标量函数 f 的情形中，输出误差就是 $|f(\boldsymbol{x}) - L|$。

定义中的 δ 只依赖 ε（以及固定的 f 与 $\boldsymbol{a}$），不依赖输入从哪个方向来。只要点进入半径为 δ 的去心球，函数值就必须落在 L 的 ε 范围内；点沿直线、沿曲线还是来回跳动地进入都一样。各坐标可以按不同速度趋近，行进方向也可以随位置改变，这些情形都由同一个 δ 覆盖。这样定义的极限也称联合极限，以区别于只沿某条路径或逐个坐标取的极限。

3.2.3.2 极限的判据

极限的定义要求一个误差半径同时控制全部趋近方式，直接验证往往不方便。本小节给出几种判据：序列判据把极限化为序列的收敛，路径检验与累次极限可以用来否定极限的存在，统一误差估计则用来证明极限存在。

序列判据　与一元情形一样，$\lim_{\boldsymbol{x} \to \boldsymbol{a}} F(\boldsymbol{x}) = \boldsymbol{L}$ 当且仅当：任意满足 $\boldsymbol{x}_n \in D \setminus \{\boldsymbol{a}\}$、$\boldsymbol{x}_n \to \boldsymbol{a}$ 的序列都有 $F(\boldsymbol{x}_n) \to \boldsymbol{L}$。证明只需把一元序列判据中的 $|x_n - a|$ 换成 $\|\boldsymbol{x}_n - \boldsymbol{a}\|$。

由逐坐标判据（定理 3.10），向量值或矩阵值映射的极限为 $\boldsymbol{L}$，当且仅当每个输出分量的极限是 $\boldsymbol{L}$ 的相应分量。这里分解的是输出。分别固定输

入的坐标则是另一回事：它只检查若干种趋近方式，不能保证联合极限存在，下面的例子说明了这一点。

路径检验 沿一条路径趋近基点时取出的点列只是这类序列的特例。由此可知路径检验能做什么、不能做什么。若沿两条路径得到不同的极限，就有两个序列的函数值趋于不同的数，联合极限不存在。反过来，只验证有限条路径，甚至验证全部过基点的直线，都没有覆盖全部序列，不能据此断定极限存在。

先看第一种情形：两条直线就足以否定联合极限。

示例 3.16 沿不同直线得到不同极限 令 $f(0,0)=0$，非原点处令 $f(x,y)=xy/(x^2+y^2)$。沿直线 $y=kx$（$x\neq 0$）代入，得到

$$f(x,kx)=\frac{kx^2}{x^2+k^2x^2}=\frac{k}{1+k^2}.$$

这个值不随 x 变化，却随斜率 k 变化：沿 x 轴（$k=0$）为 0，沿 $y=x$ 为 $1/2$，沿 $y=-x$ 为 $-1/2$；沿 y 轴同样为 0。所以 f 的值只取决于点所在的方向，不取决于离原点多远。原点附近再小的圆盘里，f 仍然取遍 $-1/2$ 到 $1/2$ 之间的值，原点处没有联合极限。

另一方面，固定 $y=c$ 时，$x\mapsto f(x,c)$ 在 $c\neq 0$ 时是分母不为零的有理函数，在 $c=0$ 时恒为 0，都是连续的；固定 x 同理。于是 f 的每条坐标切片都连续，f 却在原点不联合连续。

第二种情形更隐蔽：所有直线给出相同的极限，联合极限仍可能不存在。

示例 3.17 所有直线极限相同而联合极限不存在 令 $g(0,0)=0$，并在非原点处令

$$g(x,y)=\frac{x^2y}{x^4+y^2}.$$

沿 $y=kx$，当 $k\neq 0$ 时 $g(x,kx)=kx/(x^2+k^2)\to 0$；当 $k=0$ 或沿竖直轴时，函数恒为 0。所有直线给出的极限都是 0。可是沿抛物线 $y=x^2$，$g(x,x^2)=x^4/(2x^4)=1/2$。更一般地，沿 $y=cx^2$ 代入得到常数 $c/(1+c^2)$，因此原点处没有联合极限。

直线检验失败的原因如下。对 $x\neq 0$，直线 $y=kx$ 可以写成 $y=(k/x)x^2$，相当于取 $c=k/x$；靠近原点时 $c\to\infty$，函数值 $c/(1+c^2)\to 0$。函数值为 $1/2$ 的“山脊”沿抛物线 $y=x^2$ 弯进原点，每条固定直线最终都离开山脊，进入函数值很小的区域。

因此路径检验只能否定联合极限。要证明联合极限存在，需要像后面的示例 3.19那样，给出对所有路径同时有效的误差估计。图 3.1把直线路径和弯曲路径画在同一函数上，可以看到只检查直线会遗漏哪种趋近方式。

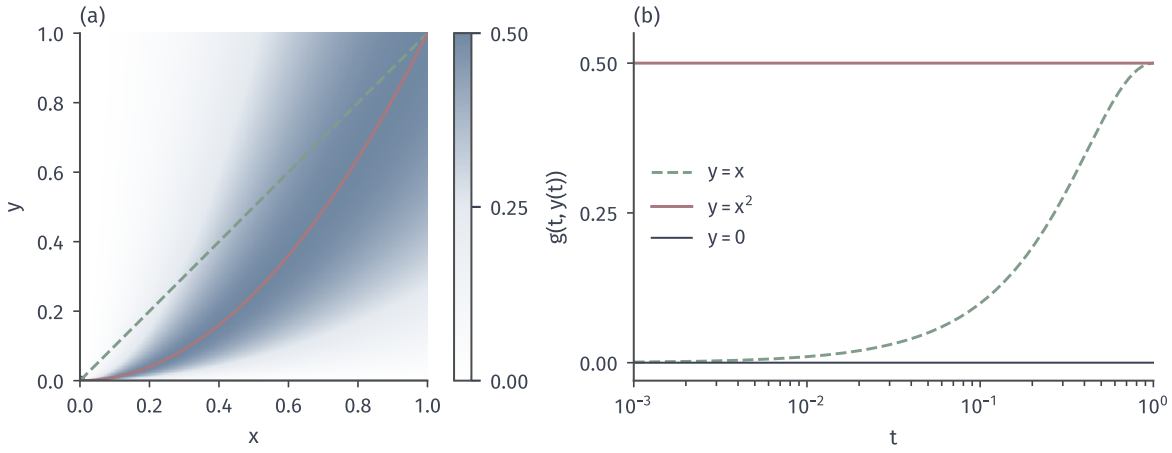


图 3.1 取前例 $g(x,y) = x^2y/(x^4+y^2)$，原点另置零。(a) 第一象限的函数值及三条路径，色阶固定为 0 至 $1/2$。(b) 沿 $y=0$、$y=x$ 分别趋零，沿 $y=x^2$ 恒为 $1/2$；横轴为正参数 t 的对数刻度，向左趋近原点。不同路径极限足以否定联合极限，有限条路径不能反向证明存在。

累次极限与联合极限 另一种常见做法是逐个坐标取极限，称为累次极限。先令 $y\to 0$、再令 $x\to 0$，得到

$$\lim_{x\to 0}\lim_{y\to 0} f(x,y).$$

内层固定 $x\neq 0$，让 y 单独趋于 0；得到一个关于 x 的函数后，外层再让 x 趋于 0。整个过程从不要求两个坐标同时趋近，因此它与联合极限是不同的问题。对示例 3.16中的 f，固定 $x\neq 0$ 时 $f(x,y)\to 0$，再令 $x\to 0$ 仍为 0；交换次序同样得到 0。两个次序的累次极限都为 0，联合极限却不存在。

累次极限的结果还可能依赖取极限的次序。

示例 3.18 两个次序的累次极限不相等 在非原点处令 $h(x,y) = x^2/(x^2+y^2)$。固定 $x\neq 0$ 而令 $y\to 0$，得到 $x^2/x^2 = 1$；固定 $y\neq 0$ 而令 $x\to 0$，得到 0。再取外层极限，

$$\lim_{x\to 0}\lim_{y\to 0} h(x,y) = 1$$

$$\lim_{y\to 0}\lim_{x\to 0} h(x,y) = 0.$$

内层先把一个坐标压到零，相当于先走到某条坐标轴附近，再沿坐标轴靠近原点。h 在 x 轴上恒为 1、在 y 轴上恒为 0，两种次序因而给出不同结果。

两个例子说明：两个次序的累次极限相等，不足以推出联合极限存在；改变次序也可能改变累次极限。

反方向在补充条件下成立。若联合极限 $\lim_{(x,y)\to(0,0)} f(x,y) = L$ 存在，并且对充分接近 0 的每个 $x \neq 0$，内层极限 $\lim_{y\to 0} f(x,y)$ 都存在，则累次极限 $\lim_{x\to 0}\lim_{y\to 0} f(x,y)$ 也存在且等于 L。理由是：给定 $\varepsilon > 0$，取联合极限定义中的 δ；当 $0 < |x| < \delta/2$、$0 < |y| < \delta/2$ 时 $|f(x,y) - L| < \varepsilon$，令 $y \to 0$，内层极限与 L 相差不超过 ε。

统一误差估计 要证明联合极限存在，可以寻找只依赖距离的上界。若 $|f(\boldsymbol{x}) - L|$ 不超过一个只与 $\|\boldsymbol{x} - \boldsymbol{a}\|_2$ 有关、并随距离趋于零的量，所有路径就同时受到控制。

示例 3.19　用距离上界证明联合极限 在非原点处考虑 $x^2y/(x^2+y^2)$。由 $|xy| \le (x^2+y^2)/2$，有

$$\left|\frac{x^2y}{x^2+y^2}\right| = |x| \cdot \frac{|xy|}{x^2+y^2} \le \frac{|x|}{2} \le \frac{1}{2}\sqrt{x^2+y^2}.$$

给定 $\varepsilon > 0$，取 $\delta = 2\varepsilon$，则距离原点小于 δ 的非原点都满足误差小于 ε，因此原点处极限为 0。

改用极坐标 $(x,y) = (r\cos\theta, r\sin\theta)$，同一函数等于 $r\cos^2\theta\sin\theta$，绝对值不超过 r。这个界对所有 θ 同时成立，给出同样的结论。

极坐标估计有效，关键在于这个界与角度无关。若只固定 θ 再令 $r \to 0$，检查的仍然只是直线。

示例 3.20　固定角度的极坐标检验 对示例 3.17中的 g，代入 $(x,y) = (r\cos\theta, r\sin\theta)$ 得到

$$g = \frac{r\cos^2\theta\sin\theta}{r^2\cos^4\theta + \sin^2\theta}.$$

固定 θ 再令 $r \to 0$：$\sin\theta \neq 0$ 时分母趋于 $\sin^2\theta$ 而分子趋于 0，$\sin\theta = 0$ 时函数恒为 0，结果总是 0。但对每个小的 $r > 0$，可以取满足 $\sin\theta = r\cos^2\theta$ 的角度。此时分子等于 $r^2\cos^4\theta$、分母等于 $2r^2\cos^4\theta$，

函数值恰为 $1/2$。这个角度随 r 改变，对应的点 $(r\cos\theta, r\sin\theta)$ 满足 $y = r^2\cos^2\theta = x^2$，正好落在抛物线上。

因此用极坐标证明联合极限时，需要一个对全部 θ 同时成立、并随 $r \to 0$ 趋于零的界。

3.2.4 连续性

3.2.4.1 连续性的定义

有了联合极限，就可以定义连续：输入联合趋近基点时，输出趋于基点处的值。定义形式与一元连续性相同，只是把 $|x-a|$ 换成输入、输出空间中的距离。

定义 3.21　映射的连续性　设 $F : D \to W$、$\boldsymbol{a} \in D$。若对每个 $\varepsilon > 0$ 都存在 $\delta > 0$，使

$$\boldsymbol{x} \in D, \quad \|\boldsymbol{x} - \boldsymbol{a}\| < \delta \Longrightarrow \|F(\boldsymbol{x}) - F(\boldsymbol{a})\| < \varepsilon,$$

则称 F 在 $\boldsymbol{a}$ 处连续；在 D 上每点连续时称 F 为连续映射，标量输出时也称连续函数。

条件中允许 $\boldsymbol{x} = \boldsymbol{a}$。在聚点处，这等价于联合极限等于 $F(\boldsymbol{a})$；在孤立点处，取足够小的 δ 使球内只有 $\boldsymbol{a}$，定义自动成立。与极限一样，F 连续当且仅当每个输出分量连续。几何上，连续意味着曲面在 $\boldsymbol{a}$ 上方没有裂缝或跳跃：从任何方向走近，高度都平稳地接近 $f(\boldsymbol{a})$。连续函数的每条坐标切片都连续，但反过来不成立：示例 3.16中各条切片都连续，函数在原点却不连续。

3.2.4.2 连续性的性质

连续性在常用运算下保持。下面逐条检验和、差、数乘、积、商、乘积型运算与复合，再用它们说明求逆在可逆矩阵上连续。

和的连续性　设 f, g 在 $\boldsymbol{a}$ 处连续。由三角不等式，

$$|(f+g)(\boldsymbol{x}) - (f+g)(\boldsymbol{a})| \le |f(\boldsymbol{x}) - f(\boldsymbol{a})| + |g(\boldsymbol{x}) - g(\boldsymbol{a})|.$$

给定 $\varepsilon > 0$，分别取使两个误差都小于 $\varepsilon/2$ 的半径，其中较小的半径就满足 $f+g$ 的连续性要求。

差的连续性 相减时两项的误差仍按三角不等式相加：$|(f-g)(\boldsymbol{x})-(f-g)(\boldsymbol{a})| \le |f(\boldsymbol{x})-f(\boldsymbol{a})| + |g(\boldsymbol{x})-g(\boldsymbol{a})|$。取与和相同的半径，即得 $f-g$ 在 $\boldsymbol{a}$ 处连续。

数乘的连续性 对固定实数 c，有 $|cf(\boldsymbol{x})-cf(\boldsymbol{a})| = |c|\,|f(\boldsymbol{x})-f(\boldsymbol{a})|$。$c \neq 0$ 时，把 f 的误差控制在 $\varepsilon/|c|$ 以内即可；$c=0$ 时 cf 是常函数，结论直接成立。

积的连续性 若 f, g 在 $\boldsymbol{a}$ 处连续，乘积的误差可以拆成两项：

$$f(\boldsymbol{x})g(\boldsymbol{x}) - f(\boldsymbol{a})g(\boldsymbol{a}) = f(\boldsymbol{x})\big(g(\boldsymbol{x})-g(\boldsymbol{a})\big) + g(\boldsymbol{a})\big(f(\boldsymbol{x})-f(\boldsymbol{a})\big).$$

由 f 的连续性，$\boldsymbol{x}$ 足够靠近 $\boldsymbol{a}$ 时 $|f(\boldsymbol{x})| \le |f(\boldsymbol{a})| + 1$，第一项的因子 $f(\boldsymbol{x})$ 有界；两个括号又都趋于零，所以 fg 在 $\boldsymbol{a}$ 处连续。这与一元的乘积极限法则是同一个论证。

坐标函数 $\boldsymbol{x} \mapsto x_j$ 连续，因为 $|x_j - a_j| \le \|\boldsymbol{x}-\boldsymbol{a}\|_2$。多元多项式由坐标函数和常数经有限次加法与乘法得到，因此连续，例如 $x^2 + xy + y^2$。

商的连续性 除法还要防止分母变为零。若再设 $g(\boldsymbol{a}) \neq 0$，由 g 的连续性，可以取一个小球使其中 $|g(\boldsymbol{x})| > |g(\boldsymbol{a})|/2$，即 g 在基点附近远离零。于是

$$\left|\frac{1}{g(\boldsymbol{x})} - \frac{1}{g(\boldsymbol{a})}\right| = \frac{|g(\boldsymbol{x})-g(\boldsymbol{a})|}{|g(\boldsymbol{x})|\,|g(\boldsymbol{a})|} \le \frac{2|g(\boldsymbol{x})-g(\boldsymbol{a})|}{g(\boldsymbol{a})^2} \longrightarrow 0,$$

所以 $1/g$ 在 $\boldsymbol{a}$ 处连续，再用积的连续性得到 f/g 连续。分母非零的条件不能省略，否则商在基点没有定义；由此，有理函数在分母非零处连续。

内积与矩阵乘法 向量值与矩阵值映射的乘积同样保持连续。若 F, G 在 $\boldsymbol{a}$ 处连续，取值为同维向量，则 $\boldsymbol{x} \mapsto F(\boldsymbol{x})^{\top} G(\boldsymbol{x})$ 在 $\boldsymbol{a}$ 处连续；若 F, G 取矩阵值且形状相容，则 $\boldsymbol{x} \mapsto F(\boldsymbol{x})G(\boldsymbol{x})$ 在 $\boldsymbol{a}$ 处连续。理由是结果的每个元素都是有限个分量乘积之和，由和与积的连续性及逐分量判据得到。

复合映射 若 $F : D \to W$ 在 $\boldsymbol{a}$ 处连续，映射 G 在 $F(\boldsymbol{a})$ 处连续，且 F 在 $\boldsymbol{a}$ 附近的输出都在 G 的定义域内，则 $G \circ F$ 在 $\boldsymbol{a}$ 处连续。证明分两步控制误差。给定 $\varepsilon > 0$，先由 G 的连续性取 $\eta > 0$，使中间值与 $F(\boldsymbol{a})$ 相差小于 η 时，G 的输出误差小于 ε；再由 F 的连续性取 $\delta > 0$，使输入距离小于 δ 时，F 的输出与 $F(\boldsymbol{a})$ 相差小于 η。合并两步，$\|\boldsymbol{x}-\boldsymbol{a}\| < \delta$ 时就有 $\|G(F(\boldsymbol{x})) - G(F(\boldsymbol{a}))\| < \varepsilon$。例如 $e^{-(x^2+y^2)}$ 和 $\sqrt{1+x^2+y^2}$ 都是一元连续函数与多项式的复合，因而在整个平面上连续。

逆映射 矩阵的函数也可以用这些规则检验。记 $\mathcal{G}=\{\boldsymbol{X}\in\mathbb{R}^{n\times n}:\det\boldsymbol{X}\neq 0\}$。由定理 1.31，在 $\mathcal{G}$ 上

$$\boldsymbol{X}^{-1}=\frac{\operatorname{adj}(\boldsymbol{X})}{\det\boldsymbol{X}}.$$

$\det\boldsymbol{X}$ 与 $\operatorname{adj}(\boldsymbol{X})$ 的每个元素都是 $\boldsymbol{X}$ 各元素的多项式，因而连续；在 $\mathcal{G}$ 上分母非零，由商的连续性，$\boldsymbol{X}^{-1}$ 的每个元素都连续。由逐分量判据，求逆 $\boldsymbol{X}\mapsto\boldsymbol{X}^{-1}$ 在可逆矩阵集合上连续。

3.2.4.3 一致连续与 Lipschitz 连续

连续性允许 δ 随基点改变。有时需要在整个定义域上统一控制误差，或者给出误差的数量关系。

定义 3.22 一致连续与 Lipschitz 连续 设 $F:D\to W$。若对每个 $\varepsilon>0$ 存在不依赖基点的 $\delta>0$，使 $\boldsymbol{x},\boldsymbol{y}\in D$、$\|\boldsymbol{x}-\boldsymbol{y}\|<\delta$ 时 $\|F(\boldsymbol{x})-F(\boldsymbol{y})\|<\varepsilon$，就称 F 在 D 上**一致连续**。若存在常数 $L\geq 0$，使

$$\|F(\boldsymbol{x})-F(\boldsymbol{y})\|\leq L\|\boldsymbol{x}-\boldsymbol{y}\|\qquad(\boldsymbol{x},\boldsymbol{y}\in D),$$

就称 F 在 D 上**Lipschitz 连续**，L 称为 Lipschitz 常数。若每点都有一个邻域，使 F 在该邻域与 D 的交上 Lipschitz 连续，就称 F 局部 *Lipschitz* 连续。

Lipschitz 连续蕴含一致连续：取 $\delta=\varepsilon/L$（$L=0$ 时任取）即可。反过来不成立：$\sqrt{x}$ 在 $[0,1]$ 上连续，下一小节将说明它一致连续，但 $|\sqrt{x}-\sqrt{0}|/|x-0|=1/\sqrt{x}$ 在 $x\to 0^{+}$ 时无界，没有 Lipschitz 常数。范数本身是 Lipschitz 连续的，由反向三角不等式，常数为 1。这里只说明误差界的含义；第 17章将用导数求出可微映射的 Lipschitz 常数。

3.2.5 闭有界集上的连续函数

连续性的一个重要用途是保证最值存在。机器学习中常在一块参数区域内最小化损失；如果最小值根本取不到，“求最小点”就没有对象。一元情形中，闭区间上的连续函数一定取到最值，关键事实是闭区间内任意点列都有收敛于该区间内的子列。本小节先把这一子列性质推广到 $\mathbb{R}^{d}$ 的闭有界集，再用它得到多元极值定理和一致连续性。矩阵空间把元素排成向量后是 $\mathbb{R}^{mn}$，结论相同。

有限维闭有界集的收敛子列 把实数列的 Bolzano–Weierstrass 定理逐个坐标使用，就得到多维点列的子列性质。其中有界性保证收敛子列存在，闭性保证极限点仍在集合内。

定理 3.23 有限维有界序列的收敛子列 若 $(\boldsymbol{x}_n)$ 是 $\mathbb{R}^d$ 中的有界序列，则存在严格递增的正整数序列 (n_k) 及 $\boldsymbol{a} \in \mathbb{R}^d$，使 $\boldsymbol{x}_{n_k} \to \boldsymbol{a}$。若所有 $\boldsymbol{x}_n$ 属于闭集 K，则 $\boldsymbol{a} \in K$。

证明 序列有界，所以每个坐标组成的实数列也有界。以 $d = 2$ 为例：先用实数列定理，从第一坐标中选出收敛子列；在这个子列中，第二坐标仍是有界实数列，再从中选出收敛的子子列。子子列的第一坐标是收敛数列的子列，仍然收敛，因此两个坐标都收敛。一般的 d 重复这一步 d 次，每次都在上一步的子列中继续选取，最后全部坐标都收敛。设各坐标极限组成 $\boldsymbol{a}$，由逐坐标判据（定理 3.10），所得子列收敛于 $\boldsymbol{a}$。若所有项都属于闭集 K，由引理 3.12，$\boldsymbol{a} \in K$。 ■

因此有限维闭有界集具有与闭区间相同的子列性质。一般度量空间中紧致与序列紧致的关系，属于度量空间的一般理论，这里不展开。

有界性与极值达到 要让上、下确界由定义域内的点取得，必须防止函数值趋近确界的输入序列逃出定义域。这样的序列可能跑向无穷远，也可能趋向一个不属于定义域的边界点。闭有界集的子列性质同时排除了这两种情况。

定理 3.24 闭有界集上的极值定理 设 $K \subseteq \mathbb{R}^d$ 非空、闭且有界，$f : K \to \mathbb{R}$ 连续，则 f 有界，且存在 $\boldsymbol{x}_{\min}, \boldsymbol{x}_{\max} \in K$ 满足

$$f(\boldsymbol{x}_{\min}) \le f(\boldsymbol{x}) \le f(\boldsymbol{x}_{\max}) \qquad (\boldsymbol{x} \in K).$$

证明 一元闭区间上最值定理的证明只用到两件事：定义域内任意点列有收敛于定义域内的子列，以及函数连续。这里的 K 由定理 3.23满足同一子列条件，输出仍为实数，所以该证明逐字适用。例如对最大值，取 $\boldsymbol{x}_n \in K$ 使 $f(\boldsymbol{x}_n)$ 趋于上确界，选出收敛子列 $\boldsymbol{x}_{n_k} \to \boldsymbol{x}_{\max} \in K$，连续性给出 $f(\boldsymbol{x}_{\max})$ 等于上确界。 ■

定理的条件只是充分条件，但删去其中任何一个，结论都可能失败。与一元情形一样，可以逐项构造反例。

示例 3.25　删去闭性、有界性或连续性时最值可能取不到　在开单位圆盘 $\{x^2+y^2<1\}$ 上，连续函数 $f(x,y)=x^2+y^2$ 的上确界为 1，但趋近上确界的点跑向不属于圆盘的边界圆，最大值取不到；这说明不能删去闭性。在闭而无界的整个平面上，$f(x,y)=-(x^2+y^2)$ 在远处无限变小，没有下界；这说明不能删去有界性。在闭单位圆盘上，令 $f(x,y)=x^2+y^2$（$x^2+y^2<1$），并在边界圆上令 $f=0$。定义域闭且有界，但 f 在边界圆上不连续，上确界 1 仍取不到；这说明不能删去连续性。

单位球面 $\{\boldsymbol{x}:\|\boldsymbol{x}\|_2=1\}$ 是闭有界集，下一节就在它上面用这个定理比较范数。

一致连续性　一元情形中，闭区间上的连续函数一致连续。同样，闭有界集上的连续映射一致连续（定义 3.22），证明仍然只用子列性质。

定理 3.26　闭有界集上的一致连续性　设 $K\subseteq\mathbb{R}^d$ 非空、闭且有界，$F:K\to W$ 连续，则 F 在 K 上一致连续。

证明　若不然，存在 $\varepsilon_0>0$，使每个 $\delta=1/n$ 都对应 $\boldsymbol{x}_n,\boldsymbol{y}_n\in K$，满足 $\|\boldsymbol{x}_n-\boldsymbol{y}_n\|<1/n$ 而 $\|F(\boldsymbol{x}_n)-F(\boldsymbol{y}_n)\|\geq\varepsilon_0$。由定理 3.23取收敛子列 $\boldsymbol{x}_{n_k}\to\boldsymbol{x}\in K$，则 $\|\boldsymbol{y}_{n_k}-\boldsymbol{x}\|\leq\|\boldsymbol{y}_{n_k}-\boldsymbol{x}_{n_k}\|+\|\boldsymbol{x}_{n_k}-\boldsymbol{x}\|\to 0$。由 F 在 $\boldsymbol{x}$ 处连续，$F(\boldsymbol{x}_{n_k})$ 与 $F(\boldsymbol{y}_{n_k})$ 都趋于 $F(\boldsymbol{x})$，两者之差趋于零，与 ε_0 矛盾。 ■

第 21章的 Riemann 和、参数积分与换元，都要在整个区域上统一控制局部近似的误差，用到的正是一致连续性。

3.3　有限维赋范空间的性质

本节研究范数与有限维线性结构结合后得到的分析性质。先证明范数等价和完备性，使向量与矩阵级数有统一的依据；再用算子范数度量线性映射，用对偶范数度量线性泛函；最后在商空间上建立范数，并证明一般范数下最近点存在。每一步都使用上一节的收敛与连续性。

3.3.1　有限维范数等价

上一节的定义都固定了欧氏范数或 Frobenius 范数。第 3.1节却给出了许多范数，误差分析也常用 ℓ_1、ℓ_∞ 或诱导矩阵范数。换用范数会不会改变收

敛与连续性？本小节证明，在有限维空间中不会。证明的关键是闭有界集上的极值定理。

定理 3.27　有限维范数等价　有限维实线性空间上任意两个范数 p, q 都等价：存在常数 $c, C > 0$，使 $c\,q(\boldsymbol{x}) \le p(\boldsymbol{x}) \le C\,q(\boldsymbol{x})$ 对所有 $\boldsymbol{x}$ 成立。

证明　零维空间只有零向量，结论显然；下设 $\dim V = d \ge 1$。思路是把每个范数都与一个固定的参照比较。固定基 $(\boldsymbol{b}_1, \dots, \boldsymbol{b}_d)$，把 $\boldsymbol{x} = \sum_j x_j \boldsymbol{b}_j$ 等同于坐标向量 $(x_1, \dots, x_d)^{\top}$，取坐标的欧氏长度 $\|\boldsymbol{x}\|_c = (\sum_j x_j^2)^{1/2}$ 作参照。按 $\|\cdot\|_c$ 收敛，就是坐标向量在 $\mathbb{R}^d$ 中收敛。

上界。对任意范数 p，由三角不等式、齐次性与 $p = q = 2$ 的 Hölder 不等式，

$$p(\boldsymbol{x}) = p\Big(\sum_j x_j \boldsymbol{b}_j\Big) \le \sum_j |x_j|\, p(\boldsymbol{b}_j) \le C_p \|\boldsymbol{x}\|_c,$$

$$C_p = \Big(\sum_j p(\boldsymbol{b}_j)^2\Big)^{1/2}.$$

由反向三角不等式，$|p(\boldsymbol{x}) - p(\boldsymbol{y})| \le p(\boldsymbol{x} - \boldsymbol{y}) \le C_p \|\boldsymbol{x} - \boldsymbol{y}\|_c$，所以 p 作为坐标的实值函数连续。这一步没有用到待证的结论。

下界。坐标单位球面 $S = \{\boldsymbol{x} : \|\boldsymbol{x}\|_c = 1\}$ 对应 $\mathbb{R}^d$ 中的欧氏单位球面，非空、闭且有界。由定理 3.24，连续函数 p 在 S 上取到最小值：存在 $\boldsymbol{x}^\star \in S$，使 $m_p = p(\boldsymbol{x}^\star) \le p(\boldsymbol{x})$ 对一切 $\boldsymbol{x} \in S$ 成立。$\boldsymbol{x}^\star \neq \boldsymbol{0}$，由范数的正定性，$m_p > 0$。对任意 $\boldsymbol{x} \neq \boldsymbol{0}$，$\boldsymbol{x}/\|\boldsymbol{x}\|_c$ 在 S 上，由齐次性得 $p(\boldsymbol{x}) \ge m_p \|\boldsymbol{x}\|_c$。合起来，

$$m_p \|\boldsymbol{x}\|_c \le p(\boldsymbol{x}) \le C_p \|\boldsymbol{x}\|_c. \tag{3.2}$$

最后比较 p 与 q：$p \le C_p \|\cdot\|_c \le (C_p/m_q)\, q$；交换 p, q 的角色，得反向不等式。 ∎

定理中的常数依赖维数与所选范数，示例 3.8说明 ℓ_1 与 ℓ_∞ 之间的常数 1 与 d 不能改进。证明中真正依赖有限维的是下界：要在单位球面上取到正的最小值，用的是有限维闭有界集上的极值定理。

收敛与连续性不依赖范数　在 V 上任取范数 $\|\cdot\|$，同样用 $\|\boldsymbol{x}_k - \boldsymbol{x}\| \to 0$ 定义收敛。换用另一个范数，误差只乘以夹在两个正常数之间的因子，所以序列是否收敛、收敛到哪里都不变。映射的极限与连续性也是如此：输入

端与输出端的范数可以分别更换，定义中的 δ 与 ε 只需乘以相应常数。开集、闭集与有界集也都与范数无关。

换一组基，新基下坐标的欧氏长度仍是 V 上的范数（第 3.1.1节借助坐标定义范数的方法）。所以逐坐标判据与所选的基无关：在任意基下，收敛都等价于逐坐标收敛。矩阵序列在任意矩阵范数（包括诱导范数）下收敛，都等价于逐元素收敛。有界序列抽取收敛子列（定理 3.23）与闭有界集上的极值定理，也可以在任何范数下使用。

不变的只是这些定性结论。数值误差与比较常数会随范数改变，常数还依赖维数，维数增长时不能视为统一的界。范数等价也不给出衰减速度：同一个收敛序列在一种范数下单调下降，在另一种范数下可能先上升。速度要在选定的范数中由具体结构估计。

3.3.2 完备性

收敛的定义要求事先知道极限。迭代算法、级数截断等过程却常常只给出一列彼此越来越接近的近似，极限是什么、是否仍在所讨论的空间里，事先并不知道。一元分析对实数列用柯西条件处理这一问题，这里把它推广到赋范空间。

Cauchy 列与完备性 赋范空间中的序列 $\boldsymbol{x}_n$ 若满足：对任意 $\varepsilon>0$，存在 N 使 $m,n>N$ 时 $\|\boldsymbol{x}_m-\boldsymbol{x}_n\|<\varepsilon$，就称为柯西列。收敛序列都是柯西列：若 $\boldsymbol{x}_n\to\boldsymbol{x}$，则 $\|\boldsymbol{x}_m-\boldsymbol{x}_n\|\le\|\boldsymbol{x}_m-\boldsymbol{x}\|+\|\boldsymbol{x}-\boldsymbol{x}_n\|$。由范数等价，有限维空间中一个序列是否为柯西列也与范数无关。柯西条件只检查序列内部，不引用任何候选极限；柯西列是否收敛，还要看空间里有没有那个极限。

若赋范空间中每个柯西列都收敛到空间中的某个元素，就称该空间**完备**（complete）；完备的赋范空间称为**Banach 空间**（Banach space，也译作巴拿赫空间）。实数在通常距离下完备，这正是实数列的柯西收敛准则：实数柯西列必收敛。有限维空间的完备性可以从实数的完备性逐坐标得到。

定理 3.28 有限维赋范空间的完备性 有限维赋范空间在任意范数下都完备，因而是 Banach 空间；它的每个子空间也完备。

证明 设 $\boldsymbol{x}^{(m)}$ 是柯西列。由式 (3.2)，$\|\boldsymbol{x}^{(m)}-\boldsymbol{x}^{(n)}\|_c\le\|\boldsymbol{x}^{(m)}-\boldsymbol{x}^{(n)}\|/m_0$，其中 $m_0>0$ 是所用范数的下界常数。每个坐标差的绝对值不超过 $\|\cdot\|_c$，所以每个坐标都是实柯西数列，由实数的完备性各有极限 x_j。令 $\boldsymbol{x}=\sum_j x_j\boldsymbol{b}_j$。由逐坐标判据，$\|\boldsymbol{x}^{(m)}-\boldsymbol{x}\|_c\to0$，再由范数等价得 $\boldsymbol{x}^{(m)}\to\boldsymbol{x}$。子空间本身也是有限维赋范空间，同样完备。矩阵空间按有限个元素得到同样的结论。 ■

证明的关键仍是有限维：坐标只有有限个，“每个坐标都收敛”才推出整个向量收敛。坐标有无穷多个时这一步会失败，无限维赋范空间未必完备，是否完备取决于空间与范数的搭配。一般度量空间的完备性属于度量空间的一般理论；函数空间在哪些范数下完备，属于本章开头提到的无限维理论。

完备性的用处在于，只要证明近似序列是柯西列，就能断定极限存在并且仍在空间中，不必事先找出极限。下一小节的级数、第 8章的矩阵幂与第 11章的迭代，都依靠这一点。

子空间的闭性 判断一个点是否属于子空间时，常常只能得到它与子空间中的点任意接近。要由此断定它属于子空间，需要子空间是闭集。

定理 3.29 有限维子空间闭性 有限维赋范空间的每个线性子空间 U 都是闭集：若 $\boldsymbol{x}_n \in U$ 且 $\boldsymbol{x}_n \to \boldsymbol{x}$，则 $\boldsymbol{x} \in U$。

证明 把 U 的基扩充为整个空间的基，则 $\boldsymbol{x}_n$ 在补充方向上的坐标恒为零。收敛等价于在这组基下逐坐标收敛，所以 $\boldsymbol{x}$ 在补充方向上的坐标是零序列的极限，仍为零，于是 $\boldsymbol{x} \in U$。 ■

这与定理 3.28一致：子空间中的柯西列在大空间中有极限，而这个极限留在闭的子空间里。记点到子空间的距离为

$$d(\boldsymbol{x}, U) = \inf_{\boldsymbol{u} \in U} \|\boldsymbol{x} - \boldsymbol{u}\|.$$

若 $d(\boldsymbol{x}, U) = 0$，可在 U 中取 $\boldsymbol{u}_n$ 使 $\|\boldsymbol{x} - \boldsymbol{u}_n\| < 1/n$，于是 $\boldsymbol{u}_n \to \boldsymbol{x}$，由闭性 $\boldsymbol{x} \in U$；反之显然。所以 $d(\boldsymbol{x}, U) = 0$ 当且仅当 $\boldsymbol{x} \in U$。

3.3.3 向量与矩阵级数的收敛

一元分析用部分和的极限定义实数级数的和。矩阵幂之和 $\sum_k \boldsymbol{A}^k$、迭代中逐步累积的误差，都是向量或矩阵的无穷和，需要同样的定义。

部分和与收敛 设 $u_0, u_1, \ldots$ 是固定有限维赋范空间 V 中的元素，可以是向量，也可以是同形矩阵。若部分和 $S_N = \sum_{k=0}^{N} u_k$ 在 V 中收敛到 S，就称级数 $\sum_{k=0}^{\infty} u_k$ 收敛，记 $\sum_{k=0}^{\infty} u_k = S$。由逐坐标判据，级数收敛当且仅当每个坐标（或元素）组成的实数级数都收敛。由 $u_N = S_N - S_{N-1}$，收敛级数的通项必趋于零。

绝对收敛　若实数级数 $\sum_k \|u_k\|$ 收敛，就称 $\sum_k u_k$ 绝对收敛。由范数等价，有限维空间中绝对收敛与所选范数无关：换用范数只把每一项的大小乘以夹在两个正常数之间的因子。

定理 3.30　绝对收敛的级数收敛　在有限维赋范空间 V 中，若 $\sum_k \|u_k\| < \infty$，则级数 $\sum_k u_k$ 收敛，并且

$$\Big\| \sum_{k=0}^{\infty} u_k - S_N \Big\| \le \sum_{k>N} \|u_k\|.$$

证明　对 $M > N$，由三角不等式，

$$\|S_M - S_N\| = \Big\| \sum_{k=N+1}^{M} u_k \Big\| \le \sum_{k=N+1}^{M} \|u_k\| \le \sum_{k>N} \|u_k\|.$$

右端是收敛实数级数的尾和，随 $N \to \infty$ 趋于零，所以 (S_N) 是柯西列。由定理 3.28，它收敛到某个 $S \in V$。在上式中令 $M \to \infty$，由范数的连续性即得尾和估计。 ■

这正是完备性的用处：不必事先知道和是什么，只要用标量级数控制各项的大小，就能断定和存在，并得到截断误差的上界。下面用一个矩阵的几何级数比较逐元素判据与绝对收敛判据。

示例 3.31　矩阵几何级数　考虑幂级数 $\sum_k \boldsymbol{A}^k$，其中

$$\boldsymbol{A} = \begin{bmatrix} 1/2 & 1 \\ 0 & 1/2 \end{bmatrix}.$$

由归纳可得 $\boldsymbol{A}^k = \begin{bmatrix} 2^{-k} & k2^{1-k} \\ 0 & 2^{-k} \end{bmatrix}$。右上角元素含有因子 k，但仍被 2^{-k} 压住。逐元素看，四个元素组成的级数 $\sum_k 2^{-k} = 2$ 与 $\sum_k k2^{1-k} = 4$ 都收敛，所以 $\sum_k \boldsymbol{A}^k$ 收敛。也可以按 Frobenius 范数估计每一项：$\|\boldsymbol{A}^k\|_{\mathrm{F}} \le \sqrt{2}\,2^{-k} + k2^{1-k}$，右端的实数级数收敛，所以这个级数还绝对收敛，定理 3.30同样适用。

把逐元素的和写回矩阵，得到

$$\sum_{k=0}^{\infty} \boldsymbol{A}^k = \begin{bmatrix} 2 & 4 \\ 0 & 2 \end{bmatrix} = (\boldsymbol{I} - \boldsymbol{A})^{-1}.$$

最后一个等式可以直接验证：$(\boldsymbol{I}-\boldsymbol{A})\begin{bmatrix}2 & 4\\ 0 & 2\end{bmatrix}=\boldsymbol{I}$。这与实数几何级数 $\sum_k a^k=(1-a)^{-1}$ 形式相同，第 8.3节将对一般方阵说明这一关系。

级数的运算 收敛级数可以逐项相加和数乘：若 $\sum_k u_k=S$、$\sum_k v_k=T$，则 $\sum_k(u_k+v_k)=S+T$、$\sum_k cu_k=cS$，因为部分和满足相应关系，再取极限。固定矩阵也可以移入求和号：若 $\sum_k \boldsymbol{U}_k=\boldsymbol{S}$，则 $\sum_k \boldsymbol{B}\boldsymbol{U}_k=\boldsymbol{B}\boldsymbol{S}$，因为部分和满足 $\sum_{k\le N}\boldsymbol{B}\boldsymbol{U}_k=\boldsymbol{B}\boldsymbol{S}_N$，而矩阵乘积保持极限。第 3.3.4节还会把这一点看作线性映射连续性的推论。一般级数的乘积与任意重排在这里不需要。

3.3.4 矩阵范数

第 1章用 Frobenius 范数衡量矩阵元素的总体大小。误差分析更常用另一种大小：把矩阵看作映射 $\boldsymbol{x}\mapsto\boldsymbol{A}\boldsymbol{x}$，问它最多把输入放大多少倍。

诱导矩阵范数 设 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$，在 $\mathbb{R}^d$ 上取输入范数 $\|\cdot\|_\alpha$，在 $\mathbb{R}^m$ 上取输出范数 $\|\cdot\|_\beta$，两者可以是任意范数。

定义 3.32　由向量范数诱导的矩阵范数 $\boldsymbol{A}$ 的诱导矩阵范数（induced matrix norm）为

$$\|\boldsymbol{A}\|_{\alpha\to\beta}=\sup_{\|\boldsymbol{x}\|_\alpha\le 1}\|\boldsymbol{A}\boldsymbol{x}\|_\beta.$$

两端采用同一类 p 范数时简写为 $\|\boldsymbol{A}\|_p$。

$d\ge 1$ 时，由齐次性，上确界也等于 $\sup_{\boldsymbol{x}\neq\boldsymbol{0}}\|\boldsymbol{A}\boldsymbol{x}\|_\beta/\|\boldsymbol{x}\|_\alpha$：单位球内的非零 $\boldsymbol{x}$ 满足 $\|\boldsymbol{A}\boldsymbol{x}\|_\beta\le\|\boldsymbol{A}(\boldsymbol{x}/\|\boldsymbol{x}\|_\alpha)\|_\beta$，零向量的贡献为零。定义域为零空间时规定范数为零。

下面先证明这个上确界有限，并由此得到线性作用的连续性。

3.3.4.1 线性作用的连续性

把矩阵作用看作映射 $\boldsymbol{x}\mapsto\boldsymbol{A}\boldsymbol{x}$，诱导范数正是它放大输入的倍数上界，因而也给出连续性的定量形式。

定理 3.33　线性作用的连续性　设 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$，$\mathbb{R}^d$ 与 $\mathbb{R}^m$ 上分别取范数 $\|\cdot\|_\alpha$ 与 $\|\cdot\|_\beta$，则：

1. 诱导范数 $\|\boldsymbol{A}\|_{\alpha\to\beta}$ 有限，并且对一切 $\boldsymbol{x}$ 有 $\|\boldsymbol{A}\boldsymbol{x}\|_\beta\le\|\boldsymbol{A}\|_{\alpha\to\beta}\|\boldsymbol{x}\|_\alpha$；
2. $\boldsymbol{x}\mapsto\boldsymbol{A}\boldsymbol{x}$ 是 Lipschitz 连续的：$\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{A}\boldsymbol{y}\|_\beta\le\|\boldsymbol{A}\|_{\alpha\to\beta}\|\boldsymbol{x}-\boldsymbol{y}\|_\alpha$；
3. 定义中的上确界可以取到：存在 $\|\boldsymbol{x}^\star\|_\alpha\le 1$，使 $\|\boldsymbol{A}\boldsymbol{x}^\star\|_\beta=\|\boldsymbol{A}\|_{\alpha\to\beta}$。

证明　第一条。把 $\boldsymbol{A}\boldsymbol{x}$ 按列展开，由三角不等式与齐次性，

$$\|\boldsymbol{A}\boldsymbol{x}\|_\beta=\Big\|\sum_j x_j\boldsymbol{A}\boldsymbol{e}_j\Big\|_\beta\le\sum_j|x_j|\,\|\boldsymbol{A}\boldsymbol{e}_j\|_\beta\le\Big(\max_j\|\boldsymbol{A}\boldsymbol{e}_j\|_\beta\Big)\|\boldsymbol{x}\|_1.$$

由范数等价，存在常数 c 使 $\|\boldsymbol{x}\|_1\le c\|\boldsymbol{x}\|_\alpha$，所以 $\|\boldsymbol{A}\boldsymbol{x}\|_\beta\le C\|\boldsymbol{x}\|_\alpha$，其中 $C=c\max_j\|\boldsymbol{A}\boldsymbol{e}_j\|_\beta$。于是单位球上的 $\|\boldsymbol{A}\boldsymbol{x}\|_\beta$ 不超过 C，上确界有限。对 $\boldsymbol{x}\neq\boldsymbol{0}$，$\boldsymbol{x}/\|\boldsymbol{x}\|_\alpha$ 在单位球上，由齐次性得所述不等式；$\boldsymbol{x}=\boldsymbol{0}$ 时两边都为零。

第二条。把第一条用于 $\boldsymbol{x}-\boldsymbol{y}$，并利用 $\boldsymbol{A}\boldsymbol{x}-\boldsymbol{A}\boldsymbol{y}=\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{y})$ 即得。

第三条。单位球 $\{\boldsymbol{x}:\|\boldsymbol{x}\|_\alpha\le 1\}$ 是闭集，由范数等价又是有界集。函数 $\boldsymbol{x}\mapsto\|\boldsymbol{A}\boldsymbol{x}\|_\beta$ 是连续的矩阵作用与连续的范数的复合，由极值定理 3.24，它在单位球上取到最大值。 ■

第一条说明，诱导范数是使 $\|\boldsymbol{A}\boldsymbol{x}\|_\beta\le C\|\boldsymbol{x}\|_\alpha$ 对全部 $\boldsymbol{x}$ 成立的最小常数：比它小的常数在取到最大值的 $\boldsymbol{x}^\star$ 处就不成立。第二条按定义 3.22把这个常数读作误差放大的上界：输入相差 $\|\boldsymbol{x}-\boldsymbol{y}\|_\alpha$ 时，输出至多相差它的 $\|\boldsymbol{A}\|_{\alpha\to\beta}$ 倍。第三条使定义中的 sup 可以写成 max。

线性映射的算子范数　对有限维赋范空间之间的线性映射 $T:V\to W$，同样定义**算子范数**（operator norm）

$$\|T\|=\sup_{\|\boldsymbol{v}\|_V\le 1}\|T\boldsymbol{v}\|_W.$$

选定 V,W 的基，并把 V,W 原有的范数搬到坐标空间（第 3.1.1节借助坐标定义范数的方法），T 由矩阵 $\boldsymbol{A}$ 表示，而 $\|T\|$ 恰等于 $\boldsymbol{A}$ 在这两个坐标范数下的诱导范数。由定理 3.33，算子范数有限并可以取到，有限维空间之间的线性映射都 Lipschitz 连续。换基而保持原空间的范数时，数值不变；若改为在坐标上指定另一种范数，就改变了大小的计量规则。

3.3.4.2 常用的诱导范数

诱导范数与把矩阵看作元素数组的 Frobenius 范数不同。常用的诱导范数有三种。

前两种可以直接从元素算出：

$$\|\boldsymbol{A}\|_1 = \max_j \sum_i |a_{i,j}|,$$
$$\|\boldsymbol{A}\|_\infty = \max_i \sum_j |a_{i,j}|,$$

即最大绝对列和与最大绝对行和，推导见下面的“列和与行和公式”。

第三种是诱导 2 范数，也称**谱范数**（spectral norm），

$$\|\boldsymbol{A}\|_2 = \sup_{\|\boldsymbol{x}\|_2=1} \|\boldsymbol{A}\boldsymbol{x}\|_2,$$

它等于最大奇异值，计算要用到第 5章的奇异值分解。下面在同一个矩阵上比较两种诱导范数与 Frobenius 范数。

示例 3.34　同一矩阵在不同口径下的大小　以剪切矩阵

$$\boldsymbol{A} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$$

为例。按列和公式，两列的绝对值之和分别为 $1+0=1$ 与 $1+1=2$；按行和公式，两行的绝对值之和分别为 $1+1=2$ 与 $0+1=1$；Frobenius 范数则把全部元素的平方相加，得 $1+1+0+1=3$。所以

$$\|\boldsymbol{A}\|_1 = \max\{1,2\} = 2,$$
$$\|\boldsymbol{A}\|_\infty = \max\{2,1\} = 2,$$
$$\|\boldsymbol{A}\|_{\mathrm{F}} = \sqrt{3}.$$

$\|\boldsymbol{A}\|_1$ 与 $\|\boldsymbol{A}\|_\infty$ 在这里碰巧相等，但分别由第二列和第一行取得，回答的是不同输入范数下的最大放大倍数；Frobenius 范数只汇总元素大小，又给出另一个数值。谈论矩阵“多大”时，须说明所用的口径。

谱范数也有直观的几何意义。如图 3.2，单位圆被 $\boldsymbol{A}$ 拉成椭圆，椭圆最长半轴的长度就是最大放大倍数。

3.3.4.3 矩阵范数的性质

有限性与可达性已由定理 3.33得到。本小节依次求出具体公式、核对范数公理，再给出乘积的上界；这些显式估计用于计算实际的误差常数。

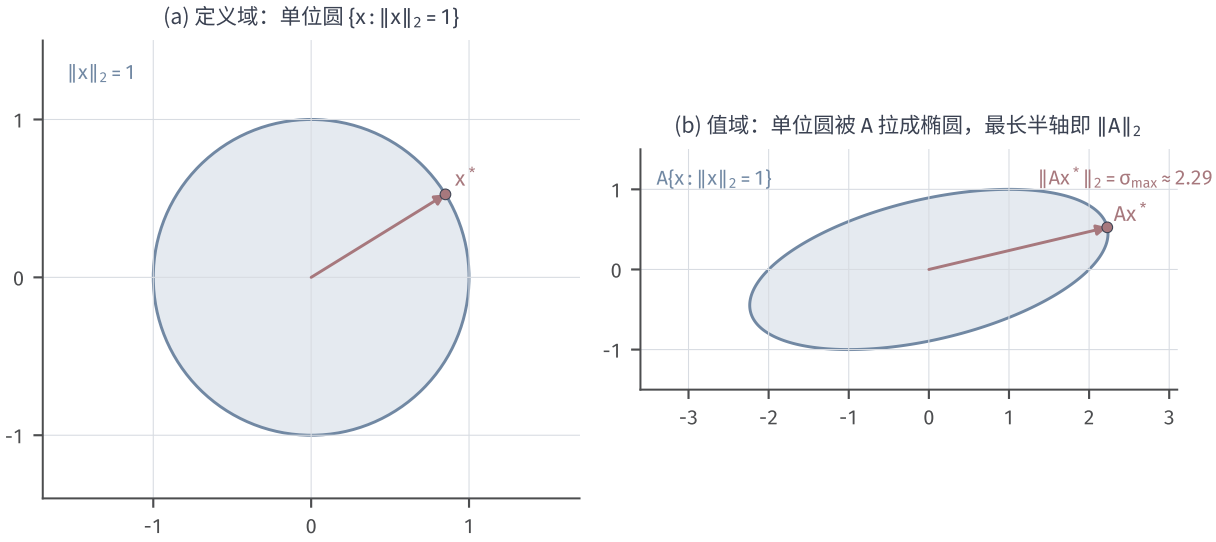


图 3.2 诱导矩阵范数衡量最坏放大倍数。左：单位圆 $\|\boldsymbol{x}\|_2 = 1$；中：线性作用 $\boldsymbol{A}$ 把单位圆映成椭圆；右：椭圆最长的半轴长度就是 $\|\boldsymbol{A}\|_2$，箭头指示最大放大方向。数值由 $\boldsymbol{A}$ 的教学构造直接得到，是解析例。

列和与行和公式 第一式按列计算：

$$\|\boldsymbol{A}\boldsymbol{x}\|_1 = \Big\|\sum_j x_j \boldsymbol{A}_{:,j}\Big\|_1 \le \sum_j |x_j|\,\|\boldsymbol{A}_{:,j}\|_1 \le \Big(\max_j \|\boldsymbol{A}_{:,j}\|_1\Big)\|\boldsymbol{x}\|_1.$$

取 $\boldsymbol{x}$ 为最大绝对列和所在列对应的标准坐标向量时，等号成立。第二式按行计算：对每个 i，

$$|(\boldsymbol{A}\boldsymbol{x})_i| \le \sum_j |a_{i,j}|\,|x_j| \le \Big(\sum_j |a_{i,j}|\Big)\|\boldsymbol{x}\|_\infty,$$

对 i 取最大值即得上界。取输入各坐标为最大绝对行和那一行元素的符号（元素为零处取 1），等号成立。

谱范数不超过 Frobenius 范数 谱范数需要奇异值才能精确计算，但 Frobenius 范数给出一个容易计算的上界：

$$\|\boldsymbol{A}\boldsymbol{x}\|_2 \le \|\boldsymbol{A}\|_{\mathrm{F}}\|\boldsymbol{x}\|_2,$$
$$\|\boldsymbol{A}\|_2 \le \|\boldsymbol{A}\|_{\mathrm{F}}.$$

对每行用 $p = q = 2$ 的 Hölder 不等式，得 $(\boldsymbol{A}\boldsymbol{x})_i^2 = (\boldsymbol{A}_{i,:}\boldsymbol{x})^2 \le \|\boldsymbol{A}_{i,:}\|_2^2\|\boldsymbol{x}\|_2^2$。对 i 求和，右侧的 $\sum_i \|\boldsymbol{A}_{i,:}\|_2^2$ 正是 $\|\boldsymbol{A}\|_{\mathrm{F}}^2$，于是得到第一式。第一式说明每个比值 $\|\boldsymbol{A}\boldsymbol{x}\|_2/\|\boldsymbol{x}\|_2$ 都不超过 $\|\boldsymbol{A}\|_{\mathrm{F}}$，由此得到第二式。

诱导范数是范数 诱导范数满足范数的各条要求。非负性与齐次性由定义直接得到。若 $\|\boldsymbol{A}\|_{\alpha\to\beta} = 0$，则每个 $\boldsymbol{A}\boldsymbol{e}_j = \boldsymbol{0}$，即 $\boldsymbol{A} = \boldsymbol{0}$，这给出正定性。

三角不等式来自 $\|(\boldsymbol{A}+\boldsymbol{B})\boldsymbol{x}\|_\beta \le \|\boldsymbol{A}\boldsymbol{x}\|_\beta + \|\boldsymbol{B}\boldsymbol{x}\|_\beta$，两边除以 $\|\boldsymbol{x}\|_\alpha$ 再取上确界即得。

次乘性 诱导范数还能控制乘积。中间范数匹配时，

$$\|\boldsymbol{A}\boldsymbol{B}\|_{\alpha\to\gamma} \le \|\boldsymbol{A}\|_{\beta\to\gamma}\|\boldsymbol{B}\|_{\alpha\to\beta}.$$

这只需连续应用两次诱导范数的界：

$$\|\boldsymbol{A}\boldsymbol{B}\boldsymbol{x}\|_\gamma \le \|\boldsymbol{A}\|_{\beta\to\gamma}\|\boldsymbol{B}\boldsymbol{x}\|_\beta \le \|\boldsymbol{A}\|_{\beta\to\gamma}\|\boldsymbol{B}\|_{\alpha\to\beta}\|\boldsymbol{x}\|_\alpha.$$

两边除以 $\|\boldsymbol{x}\|_\alpha$ 再取上确界即得。反复使用可得 $\|\boldsymbol{A}^k\|_p \le \|\boldsymbol{A}\|_p^k$。

Frobenius 范数与谱范数的混合界 乘积的 Frobenius 范数可以用一个因子的谱范数和另一个因子的 Frobenius 范数控制：

$$\begin{aligned}\|\boldsymbol{A}\boldsymbol{B}\|_{\mathrm{F}} &\le \|\boldsymbol{A}\|_2\|\boldsymbol{B}\|_{\mathrm{F}},\\ \|\boldsymbol{A}\boldsymbol{B}\|_{\mathrm{F}} &\le \|\boldsymbol{A}\|_{\mathrm{F}}\|\boldsymbol{B}\|_2.\end{aligned} \tag{3.3}$$

第一式按列计算：

$$\|\boldsymbol{A}\boldsymbol{B}\|_{\mathrm{F}}^2 = \sum_j \|\boldsymbol{A}\boldsymbol{B}_{:,j}\|_2^2 \le \|\boldsymbol{A}\|_2^2 \sum_j \|\boldsymbol{B}_{:,j}\|_2^2 = \|\boldsymbol{A}\|_2^2\|\boldsymbol{B}\|_{\mathrm{F}}^2.$$

第二式对转置应用第一式：$\|\boldsymbol{A}\boldsymbol{B}\|_{\mathrm{F}} = \|\boldsymbol{B}^{\top}\boldsymbol{A}^{\top}\|_{\mathrm{F}} \le \|\boldsymbol{B}^{\top}\|_2\|\boldsymbol{A}^{\top}\|_{\mathrm{F}}$。转置不改变 Frobenius 范数，还需要说明 $\|\boldsymbol{B}^{\top}\|_2 = \|\boldsymbol{B}\|_2$。对固定的 $\boldsymbol{x}$，由 $p=q=2$ 的 Hölder 不等式，$\|\boldsymbol{y}\|_2 = 1$ 时 $|\boldsymbol{y}^{\top}\boldsymbol{B}\boldsymbol{x}| \le \|\boldsymbol{B}\boldsymbol{x}\|_2$；$\boldsymbol{B}\boldsymbol{x} \neq \boldsymbol{0}$ 时取 $\boldsymbol{y} = \boldsymbol{B}\boldsymbol{x}/\|\boldsymbol{B}\boldsymbol{x}\|_2$ 即取等号。所以

$$\|\boldsymbol{B}\|_2 = \sup_{\|\boldsymbol{x}\|_2=\|\boldsymbol{y}\|_2=1} |\boldsymbol{y}^{\top}\boldsymbol{B}\boldsymbol{x}|.$$

由于 $\boldsymbol{y}^{\top}\boldsymbol{B}\boldsymbol{x} = \boldsymbol{x}^{\top}\boldsymbol{B}^{\top}\boldsymbol{y}$，交换 $\boldsymbol{x},\boldsymbol{y}$ 的角色，同一个上确界也等于 $\|\boldsymbol{B}^{\top}\|_2$。再结合 $\|\boldsymbol{A}\|_2 \le \|\boldsymbol{A}\|_{\mathrm{F}}$，可知 Frobenius 范数也满足次乘性：$\|\boldsymbol{A}\boldsymbol{B}\|_{\mathrm{F}} \le \|\boldsymbol{A}\|_{\mathrm{F}}\|\boldsymbol{B}\|_{\mathrm{F}}$。

3.3.5 对偶范数

第 2.4节的线性泛函是对向量的读取。有了范数，就可以衡量一个读取有多大。误差分析中的典型问题是：误差 $\boldsymbol{r}$ 只知道落在某个范数球内，一次加权读取 $\boldsymbol{z}^{\top}\boldsymbol{r}$ 最多变化多少。在 $\mathbb{R}^d$ 上取定一种范数后，这个最大值就是对偶范数。

定义 3.35 对偶范数 给定 $\mathbb{R}^d$ 上的范数，相对于标准坐标配对的对偶范数（dual norm）为

$$\|\boldsymbol{z}\|_* = \sup_{\|\boldsymbol{r}\|\le 1} |\boldsymbol{z}^{\top}\boldsymbol{r}|. \tag{3.4}$$

这就是上一小节取输出空间为 $\mathbb{R}$ 时的诱导范数：读取 $\boldsymbol{r}\mapsto \boldsymbol{z}^{\top}\boldsymbol{r}$ 是 $1\times d$ 矩阵 $\boldsymbol{z}^{\top}$ 的作用。所以对任意范数，上确界有限并且可以取到。

对偶范数满足范数的各条要求，因而是对偶空间上的范数。非负性显然。$\boldsymbol{z}\neq\boldsymbol{0}$ 时，取 $\boldsymbol{z}$ 的某个非零坐标 z_j，则 $\boldsymbol{r}=\boldsymbol{e}_j/\|\boldsymbol{e}_j\|$ 给出 $|\boldsymbol{z}^{\top}\boldsymbol{r}| = |z_j|/\|\boldsymbol{e}_j\| > 0$，这给出正定性。对每个 $\boldsymbol{r}$ 都有 $|(\boldsymbol{z}+\boldsymbol{w})^{\top}\boldsymbol{r}| \le |\boldsymbol{z}^{\top}\boldsymbol{r}| + |\boldsymbol{w}^{\top}\boldsymbol{r}|$，取上确界即得三角不等式；齐次性由 $|(c\boldsymbol{z})^{\top}\boldsymbol{r}| = |c|\,|\boldsymbol{z}^{\top}\boldsymbol{r}|$ 得到。图 3.3把这个最大值画成支撑线最后接触单位球的位置。

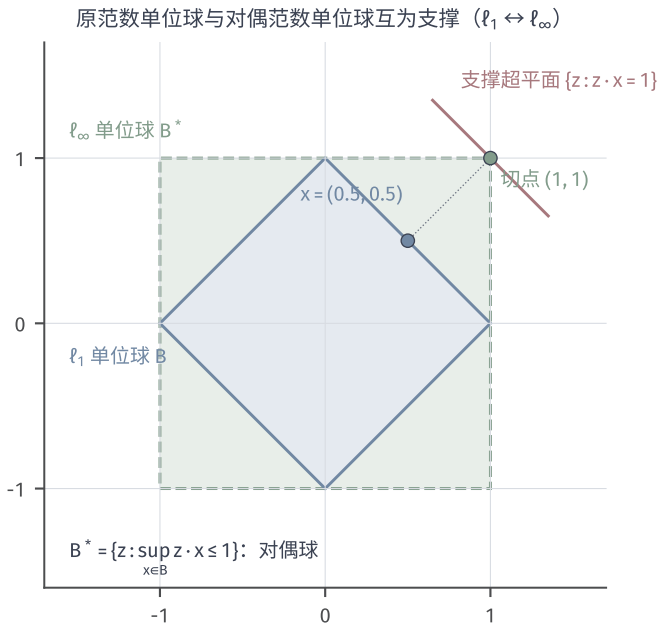


图 3.3 对偶范数的几何：在原范数单位球 $\|\boldsymbol{r}\|\le 1$ 上求线性读取 $\boldsymbol{z}^{\top}\boldsymbol{r}$ 的最大值。左：原单位球（灰色）与读取方向 $\boldsymbol{z}$；右：支撑直线最后接触单位球处给出 $\|\boldsymbol{z}\|_* = \max_{\|\boldsymbol{r}\|\le 1}|\boldsymbol{z}^{\top}\boldsymbol{r}|$。对偶单位球（虚线）与原单位球互为极体。解析教学例。

对 ℓ_p 范数，对偶范数可以明确写出：

$$(\|\cdot\|_p)_* = \|\cdot\|_q, \qquad \frac{1}{p}+\frac{1}{q}=1. \tag{3.5}$$

由齐次性，对任意预算 $\rho\ge 0$ 还有

$$\max_{\|\boldsymbol{r}\|_p\le\rho} |\boldsymbol{z}^{\top}\boldsymbol{r}| = \rho\|\boldsymbol{z}\|_q. \tag{3.6}$$

Hölder 不等式（定理 3.2）给出 ℓ_p 单位球上的上界 $\|\boldsymbol{z}\|_q$。这个上界可以达到。$1<p<\infty$ 且 $\boldsymbol{z}\neq\boldsymbol{0}$ 时，取 $r_j=|z_j|^{q-1}\operatorname{sgn}(z_j)/\|\boldsymbol{z}\|_q^{q-1}$；$\boldsymbol{z}=\boldsymbol{0}$ 时上界为零，任取可行输入即可。$p=1$ 时，把单位预算全部放在 $|z_j|$ 最大的坐标上；$p=\infty$ 时，逐坐标取 $r_j=\operatorname{sgn}(z_j)$。下面固定一个读取，比较三种误差预算。

示例 3.36　同一读取在三种误差预算下的最大变化　取读取方向 $\boldsymbol{z}=(2,-1)^{\mathsf{T}}$，即读取 $\boldsymbol{z}^{\mathsf{T}}\boldsymbol{r}=2r_1-r_2$，让误差 $\boldsymbol{r}$ 分别落在三种单位球内。

在 ℓ_1 单位球上，预算只能分给各坐标的绝对值，全部放在权重 $|z_j|$ 最大的第一个坐标最划算：$\boldsymbol{r}=(1,0)^{\mathsf{T}}$ 给出最大值 $\|\boldsymbol{z}\|_\infty=2$。在 ℓ_2 单位球上，最坏误差与 $\boldsymbol{z}$ 同方向，取 $\boldsymbol{r}=\boldsymbol{z}/\|\boldsymbol{z}\|_2=(2,-1)^{\mathsf{T}}/\sqrt{5}$，最大值为 $\|\boldsymbol{z}\|_2=\sqrt{5}$。在 ℓ_∞ 单位球上，每个坐标都可以同时取满，只需让符号与 z_j 一致：$\boldsymbol{r}=(1,-1)^{\mathsf{T}}$ 给出最大值 $\|\boldsymbol{z}\|_1=3$。换成实际的误差预算 $|r_j|\le 0.01$，就在式 (3.6)中取 $p=\infty$、$\rho=0.01$，最大变化为 $0.01\cdot(2+1)=0.03$，由 $\boldsymbol{r}=(0.01,-0.01)^{\mathsf{T}}$ 达到。

三种单位球给出的最大值依次为 2、$\sqrt{5}$、3。读取本身没有变，变的是允许误差的形状：它决定了最坏方向在哪里，也决定了读取方向要用哪个对偶范数计量。

图 3.4画出这三种情形下的最坏方向。

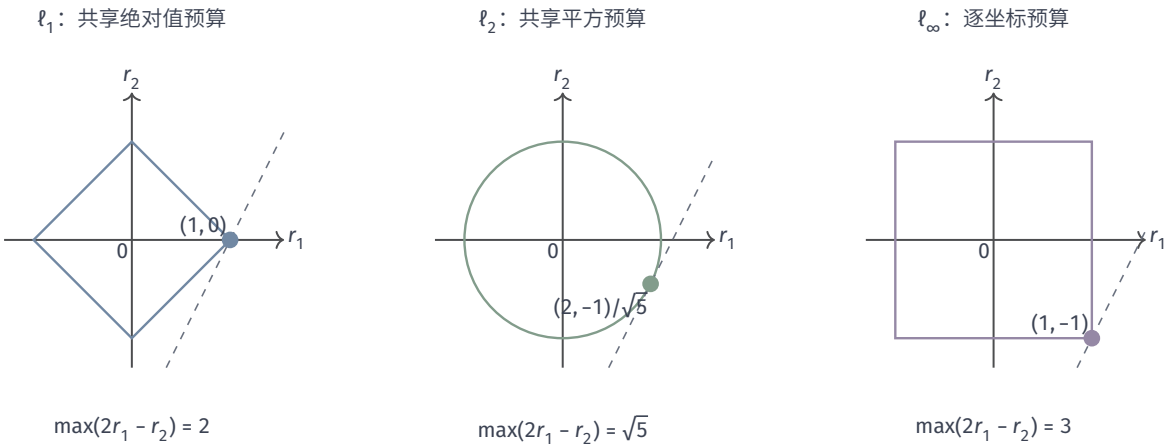


图 3.4　同一线性读取 $2r_1-r_2$ 在 ℓ_1、ℓ_2、ℓ_∞ 单位球上的最大值依次为 2、$\sqrt{5}$、3。虚线为最后接触可行集的支撑直线，点为最大化方向。三图坐标尺度相同，均为解析教学例；允许误差的形状改变时，误差常数也随之改变。

由此可见，误差预算按 ℓ_∞ 给出时，读取方向要按 ℓ_1 计量；预算按 ℓ_2 给出时，读取方向仍按 ℓ_2 计量。

原空间的范数改变，对偶范数随之改变。对加权的坐标范数，可以用换元把问题化回已知情形。

示例 3.37 加权 ℓ_1 范数的对偶范数 设权重 $w_1,\dots,w_d>0$，在 $\mathbb{R}^d$ 上取加权范数 $\|\boldsymbol{r}\|_{\boldsymbol{w}}=\sum_j w_j|r_j|$。把权重吸收进变量，令 $s_j=w_jr_j$，则 $\|\boldsymbol{r}\|_{\boldsymbol{w}}=\|\boldsymbol{s}\|_1$，$\boldsymbol{z}^{\top}\boldsymbol{r}=\sum_j(z_j/w_j)s_j$。$\boldsymbol{r}$ 取遍 $\|\boldsymbol{r}\|_{\boldsymbol{w}}\le 1$ 时，$\boldsymbol{s}$ 恰好取遍 ℓ_1 单位球。由式 (3.5)中 $p=1$ 的情形，

$$\|\boldsymbol{z}\|_*=\max_j\frac{|z_j|}{w_j}.$$

仍取上例的 $\boldsymbol{z}=(2,-1)^{\top}$。不加权，即 $\boldsymbol{w}=(1,1)^{\top}$ 时，$\|\boldsymbol{z}\|_*=2$，由 $\boldsymbol{r}=(1,0)^{\top}$ 取到，与上例的 ℓ_1 情形一致；改用 $\boldsymbol{w}=(4,1)^{\top}$ 时，$\|\boldsymbol{z}\|_*=\max\{1/2,1\}=1$，由 $\boldsymbol{r}=(0,-1)^{\top}$ 取到。

读取 $\boldsymbol{z}^{\top}\boldsymbol{r}$ 的代数表达没有变，它的大小却随原空间的范数改变。第一个坐标的权重变大后，同样的预算只允许它有更小的变化，最坏方向因而转到第二个坐标。

所以讨论“输入误差最多引起多大输出误差”时，必须先说清误差用哪种范数度量。内积诱导的范数下，对偶范数等于表示向量的长度，在第 3.6.1节证明。一般有限维空间 V 上的线性泛函 φ 同样定义 $\|\varphi\|_*=\max_{\|\boldsymbol{v}\|\le 1}|\varphi(\boldsymbol{v})|$，它是取 $W=\mathbb{R}$ 时的算子范数。无限维空间中，并非每个线性泛函都连续，代数对偶与连续对偶需要区分，这同样属于无限维理论。

3.3.6 商范数

子空间的闭性还可以用来给商空间定义范数。第 2.1.3节的商空间 V/U 把相差 U 中向量的点看成同一个类 $\boldsymbol{x}+U$，那里只建立了线性结构。要度量一个类的大小，自然的选择是类中的点到 U 的距离。这个距离不依赖类中代表元的选取：若 $\boldsymbol{x}'=\boldsymbol{x}+\boldsymbol{u}_0$，$\boldsymbol{u}_0\in U$，则 $\boldsymbol{u}$ 遍历 U 时 $\boldsymbol{u}-\boldsymbol{u}_0$ 也遍历 U，所以 $d(\boldsymbol{x}',U)=d(\boldsymbol{x},U)$。于是可以定义**商范数**（quotient norm）

$$\|\boldsymbol{x}+U\|_{V/U}=d(\boldsymbol{x},U)=\inf_{\boldsymbol{u}\in U}\|\boldsymbol{x}-\boldsymbol{u}\|.$$

它满足范数的三条要求。三角不等式：对任意 $\boldsymbol{u},\boldsymbol{u}'\in U$，

$$d(\boldsymbol{x}+\boldsymbol{y},U)\le\|(\boldsymbol{x}-\boldsymbol{u})+(\boldsymbol{y}-\boldsymbol{u}')\|\le\|\boldsymbol{x}-\boldsymbol{u}\|+\|\boldsymbol{y}-\boldsymbol{u}'\|;$$

取 $\boldsymbol{u},\boldsymbol{u}'$ 使右侧两项分别任意接近 $d(\boldsymbol{x},U)$ 与 $d(\boldsymbol{y},U)$，即得 $d(\boldsymbol{x}+\boldsymbol{y},U)\le d(\boldsymbol{x},U)+d(\boldsymbol{y},U)$。齐次性：$c\neq 0$ 时 $cU=U$，所以 $d(c\boldsymbol{x},U)=|c|\,d(\boldsymbol{x},U)$；$c=0$ 时两边都为零。正定性要求 $d(\boldsymbol{x},U)=0$ 只在 $\boldsymbol{x}+U=U$ 即 $\boldsymbol{x}\in U$ 时发生，这正是前面由子空间闭性得到的结论。在子空间不一定闭的更一般空间中，同一个公式可能只给出半范数，有限维的结论不能无条件外推。

一般范数下的最近点 商范数是一个下确界。这个下确界能否取到，就是 U 中是否存在离给定点最近的点。

定理 3.38 最近点的存在 设 V 是有限维赋范空间，U 是子空间，$\boldsymbol{x} \in V$，则存在 $\boldsymbol{u}^\star \in U$，使 $\|\boldsymbol{x}-\boldsymbol{u}^\star\| = d(\boldsymbol{x}, U)$。

证明 在 U 中取 $\boldsymbol{u}_k$，使 $\|\boldsymbol{x}-\boldsymbol{u}_k\| \to d(\boldsymbol{x}, U)$。由 $\|\boldsymbol{u}_k\| \le \|\boldsymbol{x}\| + \|\boldsymbol{x}-\boldsymbol{u}_k\|$，序列 $(\boldsymbol{u}_k)$ 有界。由定理 3.23（范数等价使它对任意范数适用），存在收敛子列 $\boldsymbol{u}_{k_i} \to \boldsymbol{u}^\star$；由子空间闭性，$\boldsymbol{u}^\star \in U$。范数连续，所以 $\|\boldsymbol{x}-\boldsymbol{u}^\star\| = \lim_i \|\boldsymbol{x}-\boldsymbol{u}_{k_i}\| = d(\boldsymbol{x}, U)$。 ■

最近点存在，却可能不唯一。

示例 3.39 反例：ℓ_∞ 范数下最近点不唯一 在 $\mathbb{R}^2$ 上取 ℓ_∞ 范数，求点 $\boldsymbol{y} = (0,1)^{\mathsf{T}}$ 到横轴 $U = \operatorname{span}\{(1,0)^{\mathsf{T}}\}$ 的最近点。U 中的点写成 $(t,0)^{\mathsf{T}}$，差向量为 $(-t,1)^{\mathsf{T}}$，于是

$$\|\boldsymbol{y} - (t,0)^{\mathsf{T}}\|_\infty = \max\{|t|, 1\} \ge 1,$$

等号当且仅当 $|t| \le 1$ 时成立。

所以 $d(\boldsymbol{y}, U) = 1$，而且横轴上整整一段 $|t| \le 1$ 的点 $(t,0)^{\mathsf{T}}$ 都是最近点。原因在于 ℓ_∞ 只看最大坐标：竖直方向的差已经是 1，水平方向的差只要不超过 1，就不影响距离。欧氏范数下只有 $t = 0$ 达到最小距离，可见最近点是否唯一取决于所用的范数，而不只取决于点和子空间。

加入内积以后，第 3.5.4节将证明正交投影给出唯一的最近点。一般范数下的存在性与内积几何下的唯一性，回答的是两个不同的问题。

3.4 内积空间

范数只度量大小，不给出角度。一般范数下谈不上两个方向是否垂直，向子空间的最近点也可能不唯一（示例 3.39）。第 1章在 $\mathbb{R}^d$ 上用逐项相乘再求和定义了欧氏内积，并由它得到长度和夹角。本节提取这种计算的共同规则，在一般线性空间上定义内积。

本节先从内积公理推出长度、夹角和几个基本不等式，再用 Gram 矩阵记录一组向量的两两内积。正交投影、标准正交基和伴随在随后两节讨论。

3.4.1 内积与内积诱导的范数

本小节先给出内积的公理和例子，再由内积定义长度、正交与夹角，最后从三角不等式出发，说明内积诱导的长度是范数，从而给出距离；平行四边形恒等式则说明，并非每个范数都来自内积。

3.4.1.1 内积的定义

欧氏内积对每个变量都保持线性组合，交换两个变量不改变结果，向量与自身的内积只在零向量处为零。这些性质只涉及线性运算，因此可以用来定义一般空间上的内积。

定义 3.40　内积空间　设 V 是实线性空间。映射 $\langle\cdot,\cdot\rangle : V\times V\to\mathbb{R}$ 若对任意 $\boldsymbol{x},\boldsymbol{y},\boldsymbol{z}\in V$ 与 $a,b\in\mathbb{R}$ 满足

1. 双线性：$\langle a\boldsymbol{x}+b\boldsymbol{y},\boldsymbol{z}\rangle = a\langle\boldsymbol{x},\boldsymbol{z}\rangle + b\langle\boldsymbol{y},\boldsymbol{z}\rangle$，且 $\langle\boldsymbol{z},a\boldsymbol{x}+b\boldsymbol{y}\rangle = a\langle\boldsymbol{z},\boldsymbol{x}\rangle + b\langle\boldsymbol{z},\boldsymbol{y}\rangle$；
2. 对称性：$\langle\boldsymbol{x},\boldsymbol{y}\rangle = \langle\boldsymbol{y},\boldsymbol{x}\rangle$；
3. 正定性：$\langle\boldsymbol{x},\boldsymbol{x}\rangle\geq 0$，且 $\langle\boldsymbol{x},\boldsymbol{x}\rangle = 0$ 当且仅当 $\boldsymbol{x}=\boldsymbol{0}$，

就称为 V 上的**内积**（inner product）；配备内积的线性空间 $(V,\langle\cdot,\cdot\rangle)$ 称为**内积空间**（inner-product space）。

内积的例子　先检验欧氏内积满足这三条公理。设 $\boldsymbol{x},\boldsymbol{y},\boldsymbol{z}\in\mathbb{R}^d$，$a,b\in\mathbb{R}$。对称性成立，因为每一项 $x_jy_j = y_jx_j$。对第一个变量的线性来自有限和的运算法则：

$$\sum_j (ax_j+bz_j)y_j = a\sum_j x_jy_j + b\sum_j z_jy_j,$$

再由对称性，对第二个变量同样成立。正定性成立，因为 $\langle\boldsymbol{x},\boldsymbol{x}\rangle = \sum_j x_j^2\geq 0$，而非负数之和为零时每一项都为零。

同形矩阵上的 Frobenius 内积也满足三条公理。它对两个变量分别线性；交换两个矩阵不改变各项乘积，因而对称；$\langle\boldsymbol{A},\boldsymbol{A}\rangle_{\mathrm{F}} = \sum_{i,j}a_{i,j}^2$ 非负，并且只在 $\boldsymbol{A}=\boldsymbol{0}$ 时为零。这正是把 mn 个元素看作坐标时欧氏内积的三条性质。所以下面从公理推出的一般结论对它同样成立。

标准内积之外，一般空间上还可以有各种内积。下面在 P_1 上规定一个只看两点取值的内积，后面的算例会反复用到它。

示例 3.41　只看两点取值的内积　在 P_1 上规定

$$\langle f, g\rangle = f(0)g(0) + f(1)g(1),$$

即把两个函数在 $t = 0, 1$ 处的取值配对相乘再相加。函数值 $f(0)$、$f(1)$ 都随 f 线性变化，所以右端对 f 与对 g 分别线性；交换 f, g 不改变右端，对称性也成立。正定性要用到 P_1 的特点：$\langle f, f\rangle = f(0)^2 + f(1)^2 \geq 0$，若它为零，则 $f(0) = f(1) = 0$；对 $f = a + bt$，这就是 $a = 0$、$a + b = 0$，故 $f = 0$。一次多项式由两个点的取值确定，这一步才能成立。

因此这一规则是 P_1 上的内积。它与系数向量 $(a, b)^{\mathsf{T}}$ 的欧氏内积并不相同：例如 $\langle 1, t\rangle = 1 \cdot 0 + 1 \cdot 1 = 1$，而 1 与 t 的系数向量 $(1, 0)^{\mathsf{T}}$、$(0, 1)^{\mathsf{T}}$ 的欧氏内积为零。同一对函数是否正交，要看采用哪种内积。

复内积的约定　上面的定义针对实空间。在复空间中，若两个变量都按复数线性，并且满足实数式的对称性，那么 $\langle \mathrm{i}\boldsymbol{x}, \mathrm{i}\boldsymbol{x}\rangle = -\langle \boldsymbol{x}, \boldsymbol{x}\rangle$，无法对非零向量保持正定。因此复内积采用另一种约定：对第一个变量共轭线性，对第二个变量线性，并满足 $\langle \boldsymbol{x}, \boldsymbol{y}\rangle = \overline{\langle \boldsymbol{y}, \boldsymbol{x}\rangle}$。标准例子是 $\langle \boldsymbol{x}, \boldsymbol{y}\rangle = \boldsymbol{x}^{*}\boldsymbol{y}$，其中 $\boldsymbol{x}^{*}$ 表示共轭转置；仍要求 $\langle \boldsymbol{x}, \boldsymbol{x}\rangle > 0$ 对非零 $\boldsymbol{x}$ 成立。

后面的 Cauchy–Schwarz 不等式在复内积下同样成立。若 $\boldsymbol{y} \neq \boldsymbol{0}$，在 $\|\boldsymbol{x} - \alpha\boldsymbol{y}\|^2 \geq 0$ 中取 $\alpha = \langle \boldsymbol{y}, \boldsymbol{x}\rangle / \|\boldsymbol{y}\|^2$，展开可得 $|\langle \boldsymbol{x}, \boldsymbol{y}\rangle|^2 \leq \|\boldsymbol{x}\|^2 \|\boldsymbol{y}\|^2$。因此它的平方根仍给出范数。但复内积的值可能不是实数，下一小节用余弦定义夹角的公式不能直接照搬。下文的证明继续使用实内积，复情形需要把转置相应改为共轭转置。

3.4.1.2 由内积定义的夹角

长度与正交　与 $\mathbb{R}^d$ 中一样，内积给出长度 $\|\boldsymbol{v}\| = \sqrt{\langle \boldsymbol{v}, \boldsymbol{v}\rangle}$，它是否满足范数的全部要求，留到下一小节检验；$\langle \boldsymbol{x}, \boldsymbol{y}\rangle = 0$ 时称 $\boldsymbol{x}, \boldsymbol{y}$ 正交。正交的两个向量满足勾股定理。展开

$$\|\boldsymbol{x} + \boldsymbol{y}\|^2 = \|\boldsymbol{x}\|^2 + 2\langle \boldsymbol{x}, \boldsymbol{y}\rangle + \|\boldsymbol{y}\|^2,$$

交叉项为零，得 $\|\boldsymbol{x} + \boldsymbol{y}\|^2 = \|\boldsymbol{x}\|^2 + \|\boldsymbol{y}\|^2$。

Cauchy–Schwarz 不等式　平面上两个非零向量的夹角 θ 满足

$$\langle \boldsymbol{x}, \boldsymbol{y}\rangle = \|\boldsymbol{x}\|\,\|\boldsymbol{y}\| \cos\theta.$$

要在一般内积空间中反过来用这个关系定义夹角，须先保证内积除以两个长度之积后总落在 $[-1, 1]$ 中。下面的不等式给出这一保证。

定理 3.42　Cauchy–Schwarz 不等式　对任一内积及其长度，任意向量 $\boldsymbol{x}, \boldsymbol{y}$ 满足

$$|\langle \boldsymbol{x}, \boldsymbol{y}\rangle| \le \|\boldsymbol{x}\|\,\|\boldsymbol{y}\|, \tag{3.7}$$

等号成立当且仅当其中一个向量是另一个向量的实数倍。

证明　$\boldsymbol{y} = \boldsymbol{0}$ 时两边都为零。设 $\boldsymbol{y} \neq \boldsymbol{0}$。对任意实数 s，向量 $\boldsymbol{x} - s\boldsymbol{y}$ 的长度平方非负；按内积的对称性与双线性展开，

$$0 \le \|\boldsymbol{x} - s\boldsymbol{y}\|^2 = \|\boldsymbol{x}\|^2 - 2s\langle \boldsymbol{x}, \boldsymbol{y}\rangle + s^2\|\boldsymbol{y}\|^2.$$

右侧是 s 的二次函数，二次项系数为正，在顶点 $s = \langle \boldsymbol{x}, \boldsymbol{y}\rangle / \|\boldsymbol{y}\|^2$ 处最小，最小值为 $\|\boldsymbol{x}\|^2 - \langle \boldsymbol{x}, \boldsymbol{y}\rangle^2/\|\boldsymbol{y}\|^2$。它非负，两边乘以 $\|\boldsymbol{y}\|^2$ 再开平方，即得不等式。等号成立当且仅当对这个 s 有 $\boldsymbol{x} - s\boldsymbol{y} = \boldsymbol{0}$，即 $\boldsymbol{x}$ 是 $\boldsymbol{y}$ 的实数倍；连同 $\boldsymbol{y} = \boldsymbol{0}$ 的情形，即得等号条件。 ■

证明只用了内积的三条公理，所以不等式对每一种内积都成立。在 $\mathbb{R}^d$ 的标准内积下，它就是 $p = q = 2$ 的 Hölder 不等式（定理 3.2）；对 Frobenius 内积，它给出 $|\langle \boldsymbol{A}, \boldsymbol{B}\rangle_{\mathrm{F}}| \le \|\boldsymbol{A}\|_{\mathrm{F}}\|\boldsymbol{B}\|_{\mathrm{F}}$。

夹角　由 Cauchy–Schwarz 不等式，非零向量的夹角 $\theta \in [0, \pi]$ 可以由

$$\cos\theta = \frac{\langle \boldsymbol{x}, \boldsymbol{y}\rangle}{\|\boldsymbol{x}\|\,\|\boldsymbol{y}\|} = \left\langle \frac{\boldsymbol{x}}{\|\boldsymbol{x}\|}, \frac{\boldsymbol{y}}{\|\boldsymbol{y}\|} \right\rangle$$

定义。第二种写法说明，夹角只比较方向：先把两个向量各自归一化为单位向量，再取内积，所以 $\boldsymbol{x}$ 与 $c\boldsymbol{x}$（$c > 0$）给出同一个方向。正交恰好对应 $\theta = \pi/2$，这就是把正交称为垂直的理由。由等号条件，$\cos\theta = \pm 1$ 恰好对应两个向量共线。分子和分母必须来自同一个内积；一边用 ℓ_2、一边用 ℓ_1 计量长度时，这个比值没有几何意义。

回到第 1章贯穿例中两个特征的取值向量，计算它们的夹角。

示例 3.43　贯穿例两列的夹角　贯穿例的两列是 $\boldsymbol{c}_1 = (1,1,1)^{\mathsf{T}}$ 与 $\boldsymbol{c}_2 = (1, 1+\varepsilon, 1-\varepsilon)^{\mathsf{T}}$，取欧氏内积。夹角公式需要一个内积和两个长度：$\langle \boldsymbol{c}_1, \boldsymbol{c}_2\rangle = 1 + (1+\varepsilon) + (1-\varepsilon) = 3$，其中 $\pm\varepsilon$ 恰好抵消；$\|\boldsymbol{c}_1\|_2^2 = 3$；$\|\boldsymbol{c}_2\|_2^2 = 1 + (1+\varepsilon)^2 + (1-\varepsilon)^2 = 3 + 2\varepsilon^2$，一次项同样抵消，只剩下二次项。所以

$$\cos\theta_\varepsilon = \frac{3}{\sqrt{3}\sqrt{3+2\varepsilon^2}} = \frac{1}{\sqrt{1+2\varepsilon^2/3}} \longrightarrow 1 \qquad (\varepsilon \to 0). \tag{3.8}$$

代入具体数值：$\varepsilon = 0.1$ 时 $\cos\theta_\varepsilon \approx 0.9967$，夹角约 $4.7°$；$\varepsilon = 0.01$ 时 $\cos\theta_\varepsilon \approx 0.99997$，夹角不到 $0.5°$。

可见 $\varepsilon \to 0$ 时两列的夹角趋于零。ε 非零时两个向量并不重合，但 ε 很小时它们几乎同向：ε 只以平方出现在余弦中，余弦与 1 只差 ε^2 量级。

两个向量不重合却几乎同向，称为**近共线**（nearly collinear）。这里的“近”指两列作为 $\mathbb{R}^3$ 中向量的夹角很小，不是说各个样本点彼此接近。夹角也依赖所用的内积：换一种内积，同样两个向量的夹角会改变。

3.4.1.3 由内积定义的距离

三角不等式 有了长度，自然想用 $\|\boldsymbol{x}-\boldsymbol{y}\|$ 度量两个向量的距离。这要求长度是一个范数，其中关键是三角不等式：从 $\boldsymbol{x}$ 到 $\boldsymbol{z}$ 的距离不超过经过 $\boldsymbol{y}$ 绕行的距离。定义 3.1的正定性直接来自内积的正定性，齐次性来自 $\langle c\boldsymbol{x}, c\boldsymbol{x}\rangle = c^2\langle \boldsymbol{x}, \boldsymbol{x}\rangle$。需要证明的是三角不等式，而 Cauchy–Schwarz 不等式正好控制展开式中的交叉项。

定理 3.44 内积诱导长度的三角不等式 设 V 是内积空间，$\|\boldsymbol{v}\| = \sqrt{\langle \boldsymbol{v}, \boldsymbol{v}\rangle}$，则对任意 $\boldsymbol{x}, \boldsymbol{y} \in V$，

$$\|\boldsymbol{x}+\boldsymbol{y}\| \le \|\boldsymbol{x}\| + \|\boldsymbol{y}\|,$$

等号成立当且仅当其中一个向量是另一个向量的非负实数倍。

证明 按双线性与对称性展开平方，再对交叉项用 $\langle \boldsymbol{x}, \boldsymbol{y}\rangle \le |\langle \boldsymbol{x}, \boldsymbol{y}\rangle|$ 与 Cauchy–Schwarz 不等式 (3.7)：

$$\begin{aligned}\|\boldsymbol{x}+\boldsymbol{y}\|^2 &= \|\boldsymbol{x}\|^2 + 2\langle \boldsymbol{x}, \boldsymbol{y}\rangle + \|\boldsymbol{y}\|^2 \\ &\le \|\boldsymbol{x}\|^2 + 2\|\boldsymbol{x}\|\|\boldsymbol{y}\| + \|\boldsymbol{y}\|^2 \\ &= (\|\boldsymbol{x}\| + \|\boldsymbol{y}\|)^2.\end{aligned}$$

两边都非负，开平方即得不等式。等号成立当且仅当 $\langle \boldsymbol{x}, \boldsymbol{y}\rangle = \|\boldsymbol{x}\|\,\|\boldsymbol{y}\|$。若 $\boldsymbol{y} = \boldsymbol{0}$，结论显然。若 $\boldsymbol{y} \neq \boldsymbol{0}$，由 Cauchy–Schwarz 不等式的等号条件，$\boldsymbol{x} = s\boldsymbol{y}$；代入得 $s\|\boldsymbol{y}\|^2 = |s|\,\|\boldsymbol{y}\|^2$，即 $s \ge 0$。反过来，$\boldsymbol{x} = s\boldsymbol{y}$ 且 $s \ge 0$ 时，两侧都等于 $(1+s)\|\boldsymbol{y}\|$。 ∎

内积诱导的范数与距离　由定理 3.44，长度 $\|\boldsymbol{v}\| = \sqrt{\langle \boldsymbol{v}, \boldsymbol{v}\rangle}$ 满足范数的三条要求，称为内积诱导的范数。它给出距离

$$d(\boldsymbol{x}, \boldsymbol{y}) = \|\boldsymbol{x} - \boldsymbol{y}\| = \sqrt{\langle \boldsymbol{x} - \boldsymbol{y}, \boldsymbol{x} - \boldsymbol{y}\rangle},$$

欧氏距离与 Frobenius 距离都是这样得到的。于是每个内积空间都是赋范空间，前三节关于范数、收敛与完备性的结论都适用于它。与一般范数相比，这个距离还可以用内积展开：$\|\boldsymbol{x} - \boldsymbol{y}\|^2 = \|\boldsymbol{x}\|^2 - 2\langle \boldsymbol{x}, \boldsymbol{y}\rangle + \|\boldsymbol{y}\|^2$，距离的平方由两个长度与夹角决定，这正是余弦定理。下面的平行四边形恒等式说明，这一额外结构可以用来区分哪些范数来自内积。

平行四边形恒等式　反过来，并非每个范数都由内积给出。内积诱导的范数还满足一条额外的等式，即**平行四边形恒等式**。几何上，它表示平行四边形两条对角线长度的平方和等于四条边长度的平方和。

定理 3.45　平行四边形恒等式　设 V 是实内积空间，$\boldsymbol{x}, \boldsymbol{y} \in V$，以该内积诱导的范数计量长度，则

$$\|\boldsymbol{x} + \boldsymbol{y}\|^2 + \|\boldsymbol{x} - \boldsymbol{y}\|^2 = 2\|\boldsymbol{x}\|^2 + 2\|\boldsymbol{y}\|^2. \tag{3.9}$$

欧氏范数是这一结论的特例。

证明　记 $\|\boldsymbol{u}\|^2 = \langle \boldsymbol{u}, \boldsymbol{u}\rangle$。由内积的双线性和对称性，分别展开和向量与差向量的长度平方：

$$\|\boldsymbol{x} + \boldsymbol{y}\|^2 = \|\boldsymbol{x}\|^2 + 2\langle \boldsymbol{x}, \boldsymbol{y}\rangle + \|\boldsymbol{y}\|^2,$$
$$\|\boldsymbol{x} - \boldsymbol{y}\|^2 = \|\boldsymbol{x}\|^2 - 2\langle \boldsymbol{x}, \boldsymbol{y}\rangle + \|\boldsymbol{y}\|^2.$$

两式相加，交叉项相互抵消，得到所需恒等式。证明只用了内积公理，因此适用于定义 3.40中的任一实内积。 ■

这条恒等式可以用来检验一个范数是否来自内积：只要某个范数在一对向量上使恒等式两侧不等，它就不可能由任何内积给出。下面用这个办法检验 ℓ_1 与 ℓ_∞ 范数。

示例 3.46　反例：ℓ_1 与 ℓ_∞ 范数不来自内积　取 $\mathbb{R}^2$ 中的两个标准坐标向量 $\boldsymbol{x} = \boldsymbol{e}_1$、$\boldsymbol{y} = \boldsymbol{e}_2$ 作为平行四边形的两条边，两条对角线分别

是 $\boldsymbol{x}+\boldsymbol{y}=(1,1)^{\top}$ 与 $\boldsymbol{x}-\boldsymbol{y}=(1,-1)^{\top}$。在 ℓ_1、ℓ_2、ℓ_∞ 范数下，四条边的长度都是 1，差别出在对角线上。对 ℓ_1 范数，两条对角线都长 2：

$$\|\boldsymbol{x}+\boldsymbol{y}\|_1^2+\|\boldsymbol{x}-\boldsymbol{y}\|_1^2=2^2+2^2=8,$$
$$2\|\boldsymbol{x}\|_1^2+2\|\boldsymbol{y}\|_1^2=2\cdot 1^2+2\cdot 1^2=4;$$

对 ℓ_∞ 范数，两条对角线都只长 1：

$$\|\boldsymbol{x}+\boldsymbol{y}\|_\infty^2+\|\boldsymbol{x}-\boldsymbol{y}\|_\infty^2=1^2+1^2=2,$$
$$2\|\boldsymbol{x}\|_\infty^2+2\|\boldsymbol{y}\|_\infty^2=4.$$

ℓ_1 范数使左侧偏大，ℓ_∞ 范数使左侧偏小，恒等式都不成立。所以不存在内积使 $\|\boldsymbol{x}\|_1=\sqrt{\langle\boldsymbol{x},\boldsymbol{x}\rangle}$ 对一切 $\boldsymbol{x}$ 成立；ℓ_∞ 范数同样不是由内积给出的长度。作为对照，欧氏范数下两条对角线长都是 $\sqrt{2}$，左侧为 4，与右侧相等。

因此一般范数只能度量大小，不能用上面的公式定义夹角。

另一方面,内积可以由它诱导的范数恢复。在实空间中,分别展开 $\|\boldsymbol{x}+\boldsymbol{y}\|^2$ 与 $\|\boldsymbol{x}-\boldsymbol{y}\|^2$ 并相减，得到极化恒等式

$$\langle\boldsymbol{x},\boldsymbol{y}\rangle=\frac{1}{4}\big(\|\boldsymbol{x}+\boldsymbol{y}\|^2-\|\boldsymbol{x}-\boldsymbol{y}\|^2\big).$$

所以两个实内积若给出同一个范数，就必相同。

Hilbert 空间　内积诱导的范数使内积空间成为赋范空间。若这个范数下的每个柯西列都收敛到空间内的元素，就称它为Hilbert 空间（Hilbert space，也译作希尔伯特空间）。

由定理 3.28，有限维内积空间都是 Hilbert 空间。后面的正交分解与正交投影都用有限维的代数构造得到，不依赖完备性。无限维空间中，完备性与子空间的闭性都需要另行检查；无限正交级数、闭子空间上的投影以及连续泛函的表示，属于本章开头提到的无限维理论。

3.4.2 Gram 矩阵

一组向量的全部两两内积可以排成一个对称矩阵，即 Gram 矩阵。本小节先引入正定与半正定矩阵，并用正定矩阵定义 $\mathbb{R}^d$ 上的加权内积；然后定义 Gram 矩阵，说明 Gram 矩阵恰好是全部半正定矩阵，从中可以读出这组向量是否线性无关、是否两两正交。借助这一刻画，可以证明逐元素乘积保持半正定。最后用基的 Gram 矩阵写出一般内积在坐标下的计算公式。

3.4.2.1 正定与半正定

n 阶对称矩阵 $\boldsymbol{M}$ 与向量 $\boldsymbol{x}\in\mathbb{R}^n$ 给出一个数

$$q(\boldsymbol{x})=\sum_{i=1}^{n}\sum_{j=1}^{n}m_{i,j}x_ix_j,$$

称为 $\boldsymbol{M}$ 的二次型；用矩阵乘法，它写作 $\boldsymbol{x}^{\top}\boldsymbol{M}\boldsymbol{x}$。

若对每个非零 $\boldsymbol{x}$ 都有 $q(\boldsymbol{x})>0$，就称 $\boldsymbol{M}$**正定**（positive definite），记作 $\boldsymbol{M}\succ\boldsymbol{0}$；若只保证 $q(\boldsymbol{x})\geq 0$ 对一切 $\boldsymbol{x}$ 成立，就称 $\boldsymbol{M}$**半正定**（positive semidefinite），记作 $\boldsymbol{M}\succeq\boldsymbol{0}$。

对两个同阶对称矩阵，$\boldsymbol{M}\succeq\boldsymbol{N}$ 表示 $\boldsymbol{M}-\boldsymbol{N}\succeq\boldsymbol{0}$，即 $\boldsymbol{M}$ 的二次型处处不小于 $\boldsymbol{N}$ 的二次型。它比较的是两个二次型，不是逐个元素。

判断正定性，要看二次型能否在某个非零向量处取到零或负值。下面用配方比较两个二阶矩阵。

示例 3.47　用配方区分正定与半正定　比较

$$\boldsymbol{M}=\begin{bmatrix}4&2\\2&2\end{bmatrix},\quad \boldsymbol{N}=\begin{bmatrix}1&1\\1&1\end{bmatrix}.$$

把二次型配成平方和，非负性一目了然，剩下的问题是平方和能否在非零向量处为零：

$$\begin{aligned}q_{\boldsymbol{M}}(\boldsymbol{x})&=4x_1^2+4x_1x_2+2x_2^2=(2x_1+x_2)^2+x_2^2,\\ q_{\boldsymbol{N}}(\boldsymbol{x})&=x_1^2+2x_1x_2+x_2^2=(x_1+x_2)^2.\end{aligned}$$

$q_{\boldsymbol{M}}$ 是两个平方之和，只在 $2x_1+x_2=0$ 且 $x_2=0$，即 $\boldsymbol{x}=\boldsymbol{0}$ 时为零，所以 $\boldsymbol{M}\succ\boldsymbol{0}$。$q_{\boldsymbol{N}}$ 只有一个平方，它处处非负，却在非零向量 $\boldsymbol{x}=(1,-1)^{\top}$ 处为零，所以 $\boldsymbol{N}\succeq\boldsymbol{0}$ 而不是正定矩阵。两个变量的二次型配出两个独立的平方项时正定，只配出一个平方项时半正定而不正定。

对角矩阵的情形最简单。它的二次型是 $\sum_i d_ix_i^2$。若全部 $d_i>0$，每个非零 $\boldsymbol{x}$ 都使它为正；若某个 $d_i\leq 0$，取 $\boldsymbol{x}=\boldsymbol{e}_i$ 就得到 $q(\boldsymbol{e}_i)=d_i\leq 0$。所以对角矩阵正定当且仅当全部 $d_i>0$，例如 $\boldsymbol{I}_n\succ\boldsymbol{0}$。

一般矩阵的正定性要对全部非零向量检查，只看元素的符号并不够。

示例 3.48 反例：元素全为正的对称矩阵未必正定 矩阵

$$\boldsymbol{M} = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}$$

的四个元素都为正，二次型为 $q(\boldsymbol{x}) = x_1^2 + 4x_1x_2 + x_2^2$。交叉项系数比两个平方项大，只要让 x_1, x_2 异号，交叉项就会占上风。取 $\boldsymbol{x} = (1, -1)^\top$，

$$q(\boldsymbol{x}) = 1^2 + 4 \cdot 1 \cdot (-1) + (-1)^2 = -2 < 0,$$

所以 $\boldsymbol{M}$ 不是正定矩阵，连半正定也不是。决定正定性的是二次型在所有方向上的取值，而不是元素的符号。

加权内积 正定矩阵可以用来在 $\mathbb{R}^d$ 上定义标准内积以外的内积。各坐标的单位或重要性不同时，可以给不同方向不同的权重：取对称正定矩阵 $\boldsymbol{M}$，规定

$$\begin{aligned} \langle \boldsymbol{x}, \boldsymbol{y} \rangle_{\boldsymbol{M}} &= \boldsymbol{x}^\top \boldsymbol{M} \boldsymbol{y}, \\ d_{\boldsymbol{M}}(\boldsymbol{x}, \boldsymbol{y}) &= \|\boldsymbol{x} - \boldsymbol{y}\|_{\boldsymbol{M}} = \sqrt{(\boldsymbol{x} - \boldsymbol{y})^\top \boldsymbol{M} (\boldsymbol{x} - \boldsymbol{y})}. \end{aligned} \tag{3.10}$$

双线性来自矩阵乘法的分配律，对称性来自 $\boldsymbol{M}^\top = \boldsymbol{M}$，正定性就是 $\boldsymbol{M}$ 的正定性。所以它满足内积的三条公理，称为加权内积，$d_{\boldsymbol{M}}$ 是它给出的距离。统计中取 $\boldsymbol{M}$ 为协方差矩阵的逆，得到的就是 Mahalanobis 距离。下面看权重怎样改变同一个点的长度。

示例 3.49 加权内积下的长度 取 $\boldsymbol{M} = \operatorname{diag}(4, 1)$，加权内积就是 $\langle \boldsymbol{x}, \boldsymbol{y} \rangle_{\boldsymbol{M}} = 4x_1y_1 + x_2y_2$，第一个坐标的乘积被计为四倍。对点 $\boldsymbol{x} = (1, 1)^\top$，$\|\boldsymbol{x}\|_{\boldsymbol{M}}^2 = 4 \cdot 1 + 1 \cdot 1 = 5$，而欧氏长度的平方只有 $1 + 1 = 2$。同一个点的加权长度是 $\sqrt{5}$，欧氏长度是 $\sqrt{2}$：权重放大了第一个坐标对长度的贡献，第一个坐标上的偏差因而比第二个坐标上同样大小的偏差显得更远。

本小节最后将说明，选定基以后，任一实内积都可以写成这种加权形式。

3.4.2.2 Gram 矩阵的定义

正交是两个向量之间的关系。一组向量 $\boldsymbol{b}_1, \dots, \boldsymbol{b}_r$ 之间有 r^2 个内积值，把它们排成一个矩阵，就能一次记录这组向量的全部相互关系。

定义 3.50 有限向量族的 Gram 矩阵 设 $\boldsymbol{b}_1, \dots, \boldsymbol{b}_r$ 是内积空间 V 中的向量。以 $g_{i,j} = \langle \boldsymbol{b}_i, \boldsymbol{b}_j \rangle$ 为元素的 r 阶矩阵 $\boldsymbol{G}$ 称为它们的Gram 矩阵（Gram matrix）。在 $\mathbb{R}^m$ 中，若 $\boldsymbol{B}$ 以这些向量为列，则欧氏内积下 $\boldsymbol{G} = \boldsymbol{B}^{\top}\boldsymbol{B}$，加权内积 $\langle \cdot, \cdot \rangle_{\boldsymbol{M}}$ 下 $\boldsymbol{G} = \boldsymbol{B}^{\top}\boldsymbol{M}\boldsymbol{B}$。

矩阵形式来自乘积的元素公式：$(\boldsymbol{B}^{\top}\boldsymbol{B})_{i,j}$ 是 $\boldsymbol{B}^{\top}$ 的第 i 行（即 $\boldsymbol{b}_i^{\top}$）与 $\boldsymbol{B}$ 的第 j 列相乘。由内积的对称性，$\boldsymbol{G}$ 是对称矩阵。

正交性写在 Gram 矩阵的非对角元里：$\boldsymbol{G}$ 是对角矩阵，恰好表示这组向量两两正交；$\boldsymbol{G} = \boldsymbol{I}_r$，则表示它们两两正交且长度都为 1。图 3.5把两个向量的两两内积排成数表。

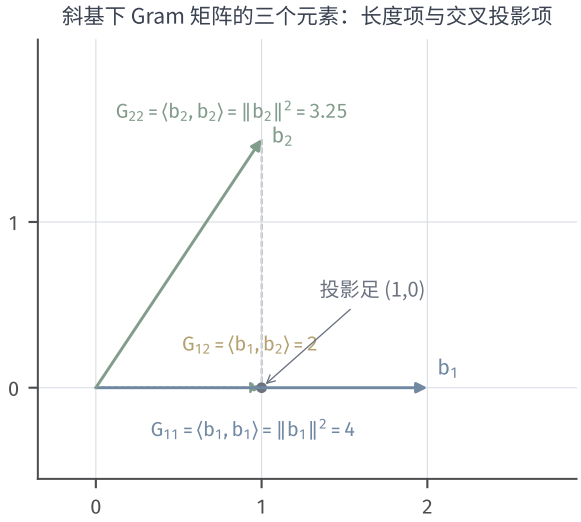


图 3.5 Gram 矩阵把一组基向量的两两内积排成数表。左：平面上两条不垂直的基向量 $\boldsymbol{b}_1, \boldsymbol{b}_2$ 及其夹角；右：$G_{i,j} = \langle \boldsymbol{b}_i, \boldsymbol{b}_j \rangle$ 构成的 2×2Gram 矩阵，对角元为各向量长度的平方，非对角元为两向量的内积。基越接近正交，非对角元越接近零；两向量共线时，某个非零组合的平方长度为零，Gram 矩阵不再正定。向量与矩阵均为解析教学例。

3.4.2.3 Gram 矩阵与半正定矩阵

Gram 矩阵的半正定性 Gram 矩阵的二次型就是线性组合的长度平方。对任意系数向量 $\boldsymbol{a} \in \mathbb{R}^r$，按双线性展开得

$$\boldsymbol{a}^{\top}\boldsymbol{G}\boldsymbol{a} = \sum_{i,j} a_i a_j \langle \boldsymbol{b}_i, \boldsymbol{b}_j \rangle = \Big\| \sum_j a_j \boldsymbol{b}_j \Big\|^2 \geq 0,$$

所以 Gram 矩阵半正定。

Gram 矩阵正定，当且仅当只有全零系数使线性组合 $\sum_j a_j \boldsymbol{b}_j$ 为零，即这组向量线性无关（第 2.2.1节）：组合为零时平方长度为零，组合非零时

平方长度为正。正定的 Gram 矩阵可逆：若 $\boldsymbol{G}\boldsymbol{a}=\boldsymbol{0}$，则 $\boldsymbol{a}^{\top}\boldsymbol{G}\boldsymbol{a}=0$，从而 $\boldsymbol{a}=\boldsymbol{0}$，零空间为零（第 2.3.3节）。

近共线在 Gram 矩阵上也有对应的表现。

示例 3.51　近共线两列的 Gram 矩阵　仍取贯穿例的两列 $\boldsymbol{c}_1,\boldsymbol{c}_2$ 与欧氏内积。示例 3.43已经算出三个内积，把它们排成矩阵，再写出二次型：

$$\boldsymbol{G}=\boldsymbol{X}_{\varepsilon}^{\top}\boldsymbol{X}_{\varepsilon}=\begin{bmatrix}3 & 3\\ 3 & 3+2\varepsilon^{2}\end{bmatrix},$$

$$\boldsymbol{a}^{\top}\boldsymbol{G}\boldsymbol{a}=3(a_1+a_2)^2+2\varepsilon^{2}a_2^{2}.$$

$\varepsilon\neq 0$ 时，二次型只在 $a_1=a_2=0$ 时为零，所以 $\boldsymbol{G}$ 正定，这与两列线性无关一致。但正定的余量很小：取 $\boldsymbol{a}=(1,-1)^{\top}$，第一个平方项消失，二次型只剩 $2\varepsilon^2$；对应的组合 $\boldsymbol{c}_1-\boldsymbol{c}_2=-\varepsilon\boldsymbol{q}$ 确实很短。近共线在 Gram 矩阵上的表现就是“正定但几乎退化”：系数不全为零，线性组合的长度平方却可以接近零。

Gram 因子定理　Gram 矩阵总是半正定的。反过来，每个半正定矩阵是否都是某组向量的 Gram 矩阵？关键是把半正定矩阵的二次型写成欧氏平方和。下面的定理用逐步配方给出这一分解。

定理 3.52　半正定矩阵的配方因子　设 $\boldsymbol{M}\in\mathbb{R}^{r\times r}$ 对称半正定，则存在 $\boldsymbol{L}\in\mathbb{R}^{r\times r}$ 使 $\boldsymbol{M}=\boldsymbol{L}^{\top}\boldsymbol{L}$；若 $\boldsymbol{M}$ 正定，可取 $\boldsymbol{L}$ 可逆。

证明　对 r 归纳。$r=1$ 时 $\boldsymbol{M}=(m_{1,1})$ 且 $m_{1,1}\geq 0$，取 $\boldsymbol{L}=(\sqrt{m_{1,1}})$ 即可。

设 $r>1$。若所有对角元都为零，任取 $i\neq j$，把 $\boldsymbol{x}=\boldsymbol{e}_i+t\boldsymbol{e}_j$ 代入半正定性：

$$0\leq \boldsymbol{x}^{\top}\boldsymbol{M}\boldsymbol{x}=m_{i,i}+2t\,m_{i,j}+t^{2}m_{j,j}=2t\,m_{i,j}.$$

这对正负 t 同时成立，迫使 $m_{i,j}=0$，于是 $\boldsymbol{M}=\boldsymbol{0}$，取 $\boldsymbol{L}=\boldsymbol{0}$。

否则存在正的对角元。取一个置换矩阵 $\boldsymbol{P}$ 把它换到首位（行列同步交换）；$\boldsymbol{P}$ 的各列是互不相同的标准坐标向量，所以 $\boldsymbol{P}^{\top}\boldsymbol{P}=\boldsymbol{P}\boldsymbol{P}^{\top}=\boldsymbol{I}$。记

$$\widetilde{\boldsymbol{M}}=\boldsymbol{P}\boldsymbol{M}\boldsymbol{P}^{\top}=\begin{bmatrix}a & \boldsymbol{b}^{\top}\\ \boldsymbol{b} & \boldsymbol{C}\end{bmatrix},$$

$$a>0.$$

$\widetilde{\boldsymbol{M}}$ 仍对称半正定，因为 $\boldsymbol{x}^{\top}\widetilde{\boldsymbol{M}}\boldsymbol{x} = (\boldsymbol{P}^{\top}\boldsymbol{x})^{\top}\boldsymbol{M}(\boldsymbol{P}^{\top}\boldsymbol{x}) \geq 0$。对第一个变量配方：令 $\boldsymbol{x} = (-\boldsymbol{b}^{\top}\boldsymbol{u}/a, \boldsymbol{u})$，展开得 $\boldsymbol{x}^{\top}\widetilde{\boldsymbol{M}}\boldsymbol{x} = \boldsymbol{u}^{\top}(\boldsymbol{C} - \boldsymbol{b}\boldsymbol{b}^{\top}/a)\boldsymbol{u} \geq 0$，故余项 $\boldsymbol{M}' = \boldsymbol{C} - \boldsymbol{b}\boldsymbol{b}^{\top}/a$ 仍半正定。由归纳假设 $\boldsymbol{M}' = \boldsymbol{L}'^{\top}\boldsymbol{L}'$，取上三角因子

$$\widetilde{\boldsymbol{L}} = \begin{bmatrix} \sqrt{a} & \boldsymbol{b}^{\top}/\sqrt{a} \\ \boldsymbol{0} & \boldsymbol{L}' \end{bmatrix},$$

按分块乘法直接相乘得

$$\widetilde{\boldsymbol{L}}^{\top}\widetilde{\boldsymbol{L}} = \begin{bmatrix} a & \boldsymbol{b}^{\top} \\ \boldsymbol{b} & \boldsymbol{b}\boldsymbol{b}^{\top}/a + \boldsymbol{L}'^{\top}\boldsymbol{L}' \end{bmatrix} = \widetilde{\boldsymbol{M}}.$$

换回原矩阵：$\boldsymbol{M} = \boldsymbol{P}^{\top}\widetilde{\boldsymbol{M}}\boldsymbol{P} = (\widetilde{\boldsymbol{L}}\boldsymbol{P})^{\top}(\widetilde{\boldsymbol{L}}\boldsymbol{P})$，取 $\boldsymbol{L} = \widetilde{\boldsymbol{L}}\boldsymbol{P}$ 即可。

正定时，$\boldsymbol{M}'$ 也正定（上述 $\boldsymbol{x}$ 在 $\boldsymbol{u} \neq \boldsymbol{0}$ 时非零），由归纳假设 $\boldsymbol{L}'$ 可逆。分块上三角矩阵 $\widetilde{\boldsymbol{L}}$ 的对角块 $\sqrt{a}$ 与 $\boldsymbol{L}'$ 都可逆，按分块乘法可以直接验证

$$\begin{bmatrix} 1/\sqrt{a} & -\boldsymbol{b}^{\top}\boldsymbol{L}'^{-1}/a \\ \boldsymbol{0} & \boldsymbol{L}'^{-1} \end{bmatrix}$$

是它的逆。于是 $\boldsymbol{L} = \widetilde{\boldsymbol{L}}\boldsymbol{P}$ 作为可逆矩阵的乘积仍可逆。 ■

下面对一个二阶正定矩阵按证明的步骤求出因子。

示例 3.53　二阶正定矩阵的配方因子　取示例 3.47中的正定矩阵

$$\boldsymbol{M} = \begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix}.$$

首个对角元 $a = 4 > 0$，不需要置换。分块后 $\boldsymbol{b} = (2)$，配方剩下的余项是 $\boldsymbol{M}' = 2 - 2^2/4 = 1$，它是一阶矩阵，取 $\boldsymbol{L}' = (1)$。代入证明中的分块形式，

$$\boldsymbol{L} = \begin{bmatrix} \sqrt{a} & \boldsymbol{b}^{\top}/\sqrt{a} \\ 0 & \boldsymbol{L}' \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix}.$$

相乘即可验证：

$$\boldsymbol{L}^{\top}\boldsymbol{L} = \begin{bmatrix} 2 & 0 \\ 1 & 1 \end{bmatrix}\begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix} = \boldsymbol{M}.$$

$\boldsymbol{L}$ 是对角元为正的上三角矩阵，因而可逆。它的两行正是配方中两个平方项的系数：

$$\boldsymbol{x}^{\top}\boldsymbol{M}\boldsymbol{x} = 4x_1^2 + 4x_1x_2 + 2x_2^2 = (2x_1 + x_2)^2 + x_2^2,$$

即 $\boldsymbol{x}^{\top}\boldsymbol{M}\boldsymbol{x} = \|\boldsymbol{L}\boldsymbol{x}\|_2^2$。证明中的分块步骤与手工配方是同一件事。

由这个分解，正定矩阵给出的加权长度可写成 $\|\boldsymbol{x}\|_{\boldsymbol{M}} = \|\boldsymbol{L}\boldsymbol{x}\|_2$：加权内积就是把 $\boldsymbol{x}$ 换成新坐标 $\boldsymbol{L}\boldsymbol{x}$ 后再量欧氏长度。证明中的配方步骤就是第 10.2节 Cholesky 分解的雏形。

半正定矩阵是 Gram 矩阵　因子定理回答了上面的问题：每个半正定矩阵都是某组向量的 Gram 矩阵。由定理 3.52，半正定的 $\boldsymbol{M}$ 可写成 $\boldsymbol{M} = \boldsymbol{L}^{\top}\boldsymbol{L}$。记 $\boldsymbol{l}_i$ 为 $\boldsymbol{L}$ 的第 i 列，则 $m_{i,j} = \boldsymbol{l}_i^{\top}\boldsymbol{l}_j = \langle \boldsymbol{l}_i, \boldsymbol{l}_j \rangle$，所以 $\boldsymbol{M}$ 正是 $\boldsymbol{l}_1, \dots, \boldsymbol{l}_r$ 在欧氏内积下的 Gram 矩阵。于是“半正定”与“是一组向量的两两内积”说的是同一件事；要判断一个矩阵半正定，可以去找这样一组向量。

3.4.2.4 Gram 矩阵的逐元素乘法

利用“半正定矩阵就是 Gram 矩阵”这一刻画，可以判断两个半正定矩阵的逐元素乘积（第 1.2.6节）是否仍然半正定。

两个半正定矩阵分别是两组向量的 Gram 矩阵；只要再找到一组向量，使它们的两两内积恰为两个 Gram 矩阵对应元素之积，就能断定乘积半正定。所得结论称为Schur 乘积定理（Schur product theorem）。

定理 3.54　Schur 乘积定理　设 $\boldsymbol{A}, \boldsymbol{B}$ 均为 n 阶对称半正定矩阵，则逐元素乘积 $\boldsymbol{A} \odot \boldsymbol{B}$ 也对称半正定。

证明　对称性由 $(\boldsymbol{A} \odot \boldsymbol{B})_{k,i} = A_{k,i}B_{k,i} = A_{i,k}B_{i,k}$ 直接得到。由定理 3.52，$\boldsymbol{A} = \boldsymbol{U}^{\top}\boldsymbol{U}$、$\boldsymbol{B} = \boldsymbol{V}^{\top}\boldsymbol{V}$；记 $\boldsymbol{u}_i, \boldsymbol{v}_i$ 分别为 $\boldsymbol{U}, \boldsymbol{V}$ 的第 i 列，则 $A_{i,k} = \langle \boldsymbol{u}_i, \boldsymbol{u}_k \rangle$、$B_{i,k} = \langle \boldsymbol{v}_i, \boldsymbol{v}_k \rangle$。考虑二阶数组 $\boldsymbol{u}_1 \otimes \boldsymbol{v}_1, \dots, \boldsymbol{u}_n \otimes \boldsymbol{v}_n$。由 Frobenius 内积下张量积配对的分离性（第 1.4.2.1节），它们的 Gram 矩阵为

$$\langle \boldsymbol{u}_i \otimes \boldsymbol{v}_i, \boldsymbol{u}_k \otimes \boldsymbol{v}_k \rangle_{\mathrm{F}} = \langle \boldsymbol{u}_i, \boldsymbol{u}_k \rangle \langle \boldsymbol{v}_i, \boldsymbol{v}_k \rangle = A_{i,k}B_{i,k}.$$

所以 $\boldsymbol{A} \odot \boldsymbol{B}$ 是 $\boldsymbol{u}_1 \otimes \boldsymbol{v}_1, \dots, \boldsymbol{u}_n \otimes \boldsymbol{v}_n$ 的 Gram 矩阵；Gram 矩阵恒半正定，故 $\boldsymbol{A} \odot \boldsymbol{B}$ 半正定。 ■

下面用一个二阶例子核对。

示例 3.55　两个半正定矩阵的逐元素乘积　取

$$\boldsymbol{A}=\boldsymbol{B}=\begin{bmatrix}1 & 1\\ 1 & 2\end{bmatrix}.$$

先确认前提：$\boldsymbol{A}$ 的二次型为 $x_1^2+2x_1x_2+2x_2^2=(x_1+x_2)^2+x_2^2\ge 0$，所以 $\boldsymbol{A}$ 半正定。逐元素相乘只把对角元 2 变成 4，乘积及其二次型为

$$\boldsymbol{A}\odot\boldsymbol{B}=\begin{bmatrix}1 & 1\\ 1 & 4\end{bmatrix},$$

$$x_1^2+2x_1x_2+4x_2^2=(x_1+x_2)^2+3x_2^2\ge 0.$$

配方后仍是平方和，$\boldsymbol{A}\odot\boldsymbol{B}$ 半正定，与定理 3.54一致。这里的配方只是核对；定理的作用在于，不必对每个乘积重新配方，就能断定结果半正定。

核方法中，两个核矩阵的逐元素乘积仍是合法的核矩阵，依据就是这一定理。

3.4.2.5　基的 Gram 矩阵与内积

选定基以后，一般内积空间上的内积由基的 Gram 矩阵完全确定。设 $\mathcal{B}=(\boldsymbol{b}_1,\dots,\boldsymbol{b}_d)$ 是 V 的基，$\boldsymbol{G}$ 是它的 Gram 矩阵。对 $\boldsymbol{v}=\sum_i x_i\boldsymbol{b}_i$、$\boldsymbol{w}=\sum_j y_j\boldsymbol{b}_j$，按双线性展开得

$$\langle\boldsymbol{v},\boldsymbol{w}\rangle=\sum_{i,j}x_iy_j\langle\boldsymbol{b}_i,\boldsymbol{b}_j\rangle=[\boldsymbol{v}]_{\mathcal{B}}^{\top}\boldsymbol{G}\,[\boldsymbol{w}]_{\mathcal{B}}.$$

基线性无关，由上一小节，$\boldsymbol{G}$ 对称正定。

因此在坐标下，任一内积都是以 $\boldsymbol{G}$ 为权重的加权内积。特别地，$\mathbb{R}^d$ 上的任一内积在标准基下都是 $\boldsymbol{x}^{\top}\boldsymbol{G}\boldsymbol{y}$，其中 $g_{i,j}=\langle\boldsymbol{e}_i,\boldsymbol{e}_j\rangle$。

反过来，每个对称正定矩阵都给出一个加权内积。所以 $\mathbb{R}^d$ 上的内积与 d 阶对称正定矩阵一一对应，欧氏内积对应 $\boldsymbol{I}$。下面用示例 3.41的内积核对坐标公式。

示例 3.56　两点内积的坐标计算　回到 P_1 上的内积 $\langle f,g\rangle=f(0)g(0)+f(1)g(1)$，取基 $(1,t)$，用两种方法计算 $f=1+t$ 与 $g=1-2t$ 的

内积。坐标公式先要基的 Gram 矩阵。由 $\langle 1,1\rangle = 1\cdot 1 + 1\cdot 1 = 2$、$\langle 1,t\rangle = 1\cdot 0 + 1\cdot 1 = 1$、$\langle t,t\rangle = 0\cdot 0 + 1\cdot 1 = 1$，得

$$\boldsymbol{G} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}.$$

直接按定义，f 在 $t = 0,1$ 处取值 $1,2$，g 取值 $1,-1$，所以 $\langle f,g\rangle = 1\cdot 1 + 2\cdot(-1) = -1$。改用坐标，$[f] = (1,1)^{\mathsf{T}}$、$[g] = (1,-2)^{\mathsf{T}}$，

$$(1,1)\,\boldsymbol{G}\begin{bmatrix} 1 \\ -2 \end{bmatrix} = (3,2)\begin{bmatrix} 1 \\ -2 \end{bmatrix} = -1.$$

两种算法给出同一个值 -1。由于 $\boldsymbol{G} \neq \boldsymbol{I}$，坐标公式中的 $\boldsymbol{G}$ 不能省去：本例中系数向量的欧氏内积碰巧也是 -1，但示例 3.41中 $\langle 1,t\rangle = 1$，系数向量的欧氏内积却是 0。

若基两两正交且长度为 1，则 $\boldsymbol{G} = \boldsymbol{I}$，内积在坐标下就是欧氏内积；这样的基在第 3.5.2节讨论。

合同变换 换基时，Gram 矩阵按另一种规则变化。若旧坐标与新坐标满足 $\boldsymbol{x} = \boldsymbol{C}\tilde{\boldsymbol{x}}$，内积中的两个坐标都要改变，因此 Gram 矩阵变为

$$\tilde{\boldsymbol{G}} = \boldsymbol{C}^{\mathsf{T}}\boldsymbol{G}\boldsymbol{C}.$$

这称为合同变换，它保持同一个内积与二次型。相似变换记录的则是同一个算子的换基，两者用途不同。

3.4.2.6 复空间中的 Gram 矩阵

前面的 Gram 矩阵都在实内积空间中讨论。按第 3.4.1.1节的约定，复内积对第一个变量共轭线性、对第二个变量线性，并满足 $\langle \boldsymbol{x},\boldsymbol{y}\rangle = \overline{\langle \boldsymbol{y},\boldsymbol{x}\rangle}$。对复内积空间中的向量 $\boldsymbol{b}_1,\dots,\boldsymbol{b}_k$，Gram 矩阵仍定义为 $G_{i,j} = \langle \boldsymbol{b}_i,\boldsymbol{b}_j\rangle$。下面说明哪些结论照样成立，哪些需要修改。

自共轭代替对称 实空间中，内积的对称性使 Gram 矩阵对称。复空间中，交换两个变量要取共轭：

$$G_{j,i} = \langle \boldsymbol{b}_j,\boldsymbol{b}_i\rangle = \overline{\langle \boldsymbol{b}_i,\boldsymbol{b}_j\rangle} = \overline{G_{i,j}},$$

即 $\boldsymbol{G}^{*} = \boldsymbol{G}$，其中 $\boldsymbol{G}^{*}$ 是共轭转置。满足 $\boldsymbol{G}^{*} = \boldsymbol{G}$ 的矩阵称为**自共轭矩阵**（Hermitian matrix），第 3.6节从伴随的角度称它为自伴矩阵。它的对角元

$G_{i,i} = \|\boldsymbol{b}_i\|^2$ 是实数，非对角元一般是复数；$\boldsymbol{G}$ 一般不对称，$\boldsymbol{G}^{\mathsf{T}} = \overline{\boldsymbol{G}}$。实 Gram 矩阵是自共轭矩阵的特例，因为实矩阵的共轭转置就是转置。

半正定性照样成立　对复系数向量 $\boldsymbol{c} \in \mathbb{C}^k$，由内积对第一个变量共轭线性、对第二个变量线性，

$$\boldsymbol{c}^{*}\boldsymbol{G}\boldsymbol{c} = \sum_{i,j} \overline{c_i}\, c_j \langle \boldsymbol{b}_i, \boldsymbol{b}_j \rangle = \Big\langle \sum_i c_i \boldsymbol{b}_i, \sum_j c_j \boldsymbol{b}_j \Big\rangle = \Big\| \sum_j c_j \boldsymbol{b}_j \Big\|^2 \geq 0.$$

这与实情形的等式完全相同，只是左端的转置换成了共轭转置。自共轭矩阵的 $\boldsymbol{c}^{*}\boldsymbol{G}\boldsymbol{c}$ 总是实数，所以“非负”有意义；称满足 $\boldsymbol{c}^{*}\boldsymbol{G}\boldsymbol{c} \geq 0$ 的自共轭矩阵为半正定。于是复 Gram 矩阵总是半正定的。

正定与线性无关的关系照样成立　由同一等式，$\boldsymbol{c}^{*}\boldsymbol{G}\boldsymbol{c} = 0$ 当且仅当 $\sum_j c_j \boldsymbol{b}_j = \boldsymbol{0}$。所以 $\boldsymbol{G}$ 正定，即 $\boldsymbol{c} \neq \boldsymbol{0}$ 时 $\boldsymbol{c}^{*}\boldsymbol{G}\boldsymbol{c} > 0$，当且仅当 $\boldsymbol{b}_1, \ldots, \boldsymbol{b}_k$ 在复数域上线性无关。这里的线性无关允许复系数：在实数域上无关的一组向量，在复数域上可能相关。例如在 $\mathbb{C}$ 中，1 与 i 在实系数下无关，但 $\mathrm{i} \cdot 1 - \mathrm{i} = 0$，在复系数下相关；对应的 Gram 矩阵 $\begin{bmatrix} 1 & \mathrm{i} \\ -\mathrm{i} & 1 \end{bmatrix}$ 的行列式为 $1 - 1 = 0$，确实不是正定的。

逐步配方的证明也保留。分块

$$\boldsymbol{G} = \begin{bmatrix} a & \boldsymbol{b}^{*} \\ \boldsymbol{b} & \boldsymbol{C} \end{bmatrix}$$

且 $a > 0$ 时，分离出的平方项为 $a|z + \boldsymbol{b}^{*}\boldsymbol{y}/a|^2$，剩余矩阵是 $\boldsymbol{C} - \boldsymbol{b}\boldsymbol{b}^{*}/a$；若对角元全为零，取只有两个分量非零且相位可调的向量，半正定性迫使所有非对角元也为零。递推便得到 $\boldsymbol{G} = \boldsymbol{L}^{*}\boldsymbol{L}$：每个半正定的自共轭矩阵都是某组向量的 Gram 矩阵，不需要借用后面的谱定理。

坐标下的内积与换基　在一组基下，复内积写成 $\langle \boldsymbol{x}, \boldsymbol{y} \rangle = \boldsymbol{x}^{*}\boldsymbol{G}\boldsymbol{y}$，其中 $\boldsymbol{x}, \boldsymbol{y}$ 表示坐标，$\boldsymbol{G}$ 是基的 Gram 矩阵，它是正定的自共轭矩阵。换基 $\boldsymbol{x} = \boldsymbol{C}\tilde{\boldsymbol{x}}$ 时，两个坐标都要改变，Gram 矩阵变为 $\boldsymbol{C}^{*}\boldsymbol{G}\boldsymbol{C}$，合同变换中的转置相应换成共轭转置。

示例 3.57　复空间中的 Gram 矩阵　在 $\mathbb{C}^2$ 上取标准内积 $\langle \boldsymbol{x}, \boldsymbol{y} \rangle = \boldsymbol{x}^{*}\boldsymbol{y}$，计算 $\boldsymbol{b}_1 = (1, \mathrm{i})^{\mathsf{T}}$ 与 $\boldsymbol{b}_2 = (1, 1)^{\mathsf{T}}$ 的 Gram 矩阵。第一个变量要取共轭：

$\langle \boldsymbol{b}_1, \boldsymbol{b}_1 \rangle = 1 + |\mathrm{i}|^2 = 2$，$\langle \boldsymbol{b}_2, \boldsymbol{b}_2 \rangle = 2$，$\langle \boldsymbol{b}_1, \boldsymbol{b}_2 \rangle = \overline{1} \cdot 1 + \overline{\mathrm{i}} \cdot 1 = 1 - \mathrm{i}$，$\langle \boldsymbol{b}_2, \boldsymbol{b}_1 \rangle = 1 + \mathrm{i}$，所以

$$\boldsymbol{G} = \begin{bmatrix} 2 & 1-\mathrm{i} \\ 1+\mathrm{i} & 2 \end{bmatrix}.$$

两个非对角元互为共轭，所以 $\boldsymbol{G}$ 不对称，但 $\boldsymbol{G}^* = \boldsymbol{G}$。再看正定性。$\boldsymbol{b}_1, \boldsymbol{b}_2$ 在复数域上线性无关：若 $\boldsymbol{b}_1 = c\boldsymbol{b}_2$，比较两个坐标得 $c = 1$ 且 $c = \mathrm{i}$，矛盾。由上面的结论，$\boldsymbol{G}$ 正定。在一个具体方向上核对：取 $\boldsymbol{c} = (1, -1)^{\mathsf{T}}$，$\boldsymbol{c}^* \boldsymbol{G} \boldsymbol{c} = 2 - (1 - \mathrm{i}) - (1 + \mathrm{i}) + 2 = 2 = \|\boldsymbol{b}_1 - \boldsymbol{b}_2\|^2 > 0$，两个虚部相互抵消，结果是实数。

这个例子显示了复情形改变的和保留的部分：Gram 矩阵从对称变为自共轭，而半正定性以及正定与线性无关的对应，都与实情形相同。

3.5 正交与投影

内积给出了两个向量之间的正交关系。本节把它推广到向量与子空间之间，把向量分解为子空间中的分量与和子空间正交的剩余部分。接着引入标准正交基，并用 Gram–Schmidt 正交化构造它；最后用标准正交基写出正交投影，证明它给出唯一的最近点。

3.5.1 正交补与正交分解

Gram 矩阵记录的是一组向量两两之间是否正交。本小节考虑一个向量与整个子空间的正交，由此得到一个由内积唯一确定的补空间，并用它证明四个基本子空间之间的垂直关系。

正交补 第 2.1.2节说明，一个子空间的补空间一般不唯一。有了内积，可以挑出一个由垂直关系确定的补空间。设 U 是有限维内积空间 V 的子空间，与 U 中每个向量都正交的向量组成集合

$$U^{\perp} = \{\boldsymbol{r} \in V : \langle \boldsymbol{u}, \boldsymbol{r} \rangle = 0,\ \forall \boldsymbol{u} \in U\},$$

称为 U 的**正交补**（orthogonal complement）。由内积的双线性，$U^{\perp}$ 对线性组合封闭，是子空间。要检查 $\boldsymbol{r} \in U^{\perp}$，只需检查它与 U 的一组基逐个正交，因为与基向量都正交的向量，也与基向量的每个组合正交。

正交直和 下面证明正交补确实是一个补空间，而且分解可以由 Gram 矩阵算出。

引理 3.58　正交直和　设 U 是有限维内积空间 V 的子空间，则每个 $\boldsymbol{x} \in V$ 唯一分解为 $\boldsymbol{x} = \boldsymbol{u} + \boldsymbol{r}$，其中 $\boldsymbol{u} \in U$、$\boldsymbol{r} \in U^{\perp}$；即 $V = U \oplus U^{\perp}$。

证明　取 U 的一组基 $\boldsymbol{b}_1, \dots, \boldsymbol{b}_r$。它线性无关，所以 Gram 矩阵 $\boldsymbol{G}$ 正定，从而可逆。对任意 $\boldsymbol{x}$，令 $\boldsymbol{u} = \sum_j a_j \boldsymbol{b}_j$，并要求 $\boldsymbol{r} = \boldsymbol{x} - \boldsymbol{u}$ 与每个 $\boldsymbol{b}_i$ 正交，得到系数方程

$$\sum_j g_{i,j} a_j = \langle \boldsymbol{b}_i, \boldsymbol{x} \rangle, \qquad i = 1, \dots, r,$$

即 $\boldsymbol{G}\boldsymbol{a} = (\langle \boldsymbol{b}_i, \boldsymbol{x} \rangle)_i$。$\boldsymbol{G}$ 可逆，所以系数唯一解出；残差 $\boldsymbol{r}$ 与全部基向量正交，因而落在 $U^{\perp}$。

若 $\boldsymbol{x} = \boldsymbol{u} + \boldsymbol{r} = \boldsymbol{u}' + \boldsymbol{r}'$ 是两种分解，则 $\boldsymbol{u} - \boldsymbol{u}' = \boldsymbol{r}' - \boldsymbol{r}$ 同时属于 U 与 $U^{\perp}$。它与自身正交，长度为零，故两种分解相同。 ■

所以正交补是 U 的一个补空间，并且由内积唯一确定；$V = U \oplus U^{\perp}$ 称为正交直和。由维数公式，$\dim U^{\perp} = \dim V - \dim U$。下面在 $\mathbb{R}^3$ 中做一次分解。

示例 3.59　向一条直线的正交分解　在 $\mathbb{R}^3$ 中取欧氏内积，把 $\boldsymbol{y} = (1, 1.1, 0.9)^{\mathsf{T}}$ 分解到直线 $U = \operatorname{span}\{\boldsymbol{c}_1\}$ 及其正交补上，其中 $\boldsymbol{c}_1 = (1, 1, 1)^{\mathsf{T}}$。与 $\boldsymbol{c}_1$ 正交就是坐标和为零，所以 $U^{\perp}$ 是坐标和为零的平面。U 只有一个基向量，Gram 方程只有一个未知数：$\langle \boldsymbol{c}_1, \boldsymbol{c}_1 \rangle a = \langle \boldsymbol{c}_1, \boldsymbol{y} \rangle$，即 $3a = 3$，所以 $a = 1$。于是

$$\boldsymbol{u} = \boldsymbol{c}_1 = (1, 1, 1)^{\mathsf{T}},$$
$$\boldsymbol{r} = \boldsymbol{y} - \boldsymbol{u} = (0, 0.1, -0.1)^{\mathsf{T}},$$

$\boldsymbol{r}$ 的坐标和为零，确实属于 $U^{\perp}$。所以 $\boldsymbol{y} = \boldsymbol{u} + \boldsymbol{r}$ 就是 $\boldsymbol{y}$ 在正交直和 $\mathbb{R}^3 = U \oplus U^{\perp}$ 中的分解：沿 $\boldsymbol{c}_1$ 方向的部分是三个坐标的公共水平 1，剩下的 $(0, 0.1, -0.1)^{\mathsf{T}}$ 记录各坐标偏离这个水平的程度。

这里只得到了正交分量的存在与唯一。它为什么是 U 中离 $\boldsymbol{y}$ 最近的点，将在第 3.5.4节用标准正交基证明。

取两次正交补会回到原来的子空间：$(U^{\perp})^{\perp} = U$。一方面，U 中每个向量与 $U^{\perp}$ 中每个向量正交，所以 $U \subseteq (U^{\perp})^{\perp}$。另一方面，对 $U^{\perp}$ 用上面的维数关系，$\dim (U^{\perp})^{\perp} = \dim V - \dim U^{\perp} = \dim U$。二者包含且同维，由第 2.2.2节，两者相等。

四个基本子空间的正交关系 示例 2.24显示，行空间的方向与零空间垂直，列空间的方向与左零空间垂直。现在在 $\mathbb{R}^d$ 与 $\mathbb{R}^m$ 上取欧氏内积，证明这对任何矩阵都成立。

定理 3.60 四个基本子空间的正交关系 设 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$，$\mathbb{R}^d$ 与 $\mathbb{R}^m$ 取欧氏内积。则

$$\begin{aligned} \operatorname{null}(\boldsymbol{A}) &= \operatorname{range}(\boldsymbol{A}^\top)^\perp, \\ \operatorname{null}(\boldsymbol{A}^\top) &= \operatorname{range}(\boldsymbol{A})^\perp, \end{aligned} \tag{3.11}$$

因而有正交直和

$$\begin{aligned} \mathbb{R}^d &= \operatorname{range}(\boldsymbol{A}^\top) \oplus \operatorname{null}(\boldsymbol{A}), \\ \mathbb{R}^m &= \operatorname{range}(\boldsymbol{A}) \oplus \operatorname{null}(\boldsymbol{A}^\top). \end{aligned} \tag{3.12}$$

证明 由转置的乘积规则（第 1.2.5.2节），对任意 $\boldsymbol{x} \in \mathbb{R}^d$、$\boldsymbol{y} \in \mathbb{R}^m$，

$$\langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle = (\boldsymbol{A}\boldsymbol{x})^\top \boldsymbol{y} = \boldsymbol{x}^\top(\boldsymbol{A}^\top \boldsymbol{y}) = \langle \boldsymbol{x}, \boldsymbol{A}^\top \boldsymbol{y}\rangle.$$

$\boldsymbol{y} \in \operatorname{range}(\boldsymbol{A})^\perp$ 意味着左端对一切 $\boldsymbol{x}$ 为零，即右端对一切 $\boldsymbol{x}$ 为零；取 $\boldsymbol{x} = \boldsymbol{A}^\top \boldsymbol{y}$ 可见，这当且仅当 $\boldsymbol{A}^\top \boldsymbol{y} = \boldsymbol{0}$。所以 $\operatorname{range}(\boldsymbol{A})^\perp = \operatorname{null}(\boldsymbol{A}^\top)$。把 $\boldsymbol{A}$ 换成 $\boldsymbol{A}^\top$，得 $\operatorname{range}(\boldsymbol{A}^\top)^\perp = \operatorname{null}(\boldsymbol{A})$。正交直和由引理 3.58得到。 ■

两边再取正交补，并用 $(U^\perp)^\perp = U$，还得到 $\operatorname{null}(\boldsymbol{A})^\perp = \operatorname{range}(\boldsymbol{A}^\top)$、$\operatorname{null}(\boldsymbol{A}^\top)^\perp = \operatorname{range}(\boldsymbol{A})$。于是输入空间分成两块互相垂直的部分：零空间是被 $\boldsymbol{A}$ 消去的方向，行空间是真正影响输出的方向。输出空间也分成两块：列空间是能够到达的输出，左零空间中的方向则无论输入取什么都无法到达。

这一定理与第 2.3.2节的维数关系相互印证。由正交直和与秩零度定理，分别得到

$$\begin{aligned} d &= \dim \operatorname{range}(\boldsymbol{A}^\top) + \dim \operatorname{null}(\boldsymbol{A}), \\ d &= \operatorname{rank} \boldsymbol{A} + \dim \operatorname{null}(\boldsymbol{A}). \end{aligned}$$

两式比较，又一次得到行秩等于列秩。示例 2.24中逐项相乘再相加得零的观察，现在由定理得到了解释。

输出端的分解还给出方程 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 有解的一个判据：$\boldsymbol{b} \in \operatorname{range}(\boldsymbol{A})$，当且仅当 $\boldsymbol{b}$ 与左零空间中每个向量正交。第 9章判断方程是否有解时会用到这一点。

3.5.2 标准正交基

前面的计算都要用到 Gram 矩阵：正交分解要解 Gram 方程 $\boldsymbol{G}\boldsymbol{a} = (\langle \boldsymbol{b}_i, \boldsymbol{x}\rangle)_i$，坐标下的内积要乘 Gram 矩阵。示例 2.16还显示，接近共线的基会把小的对象记成很大的系数。这些麻烦都来自 Gram 矩阵的非对角元，即基向量之间的相互干扰。本小节研究 Gram 矩阵为单位矩阵的基：先证明它确实是一组基，再给出它下的坐标、对应的正交矩阵，以及这类基之间的换基。

标准正交基的定义 一组向量 $\boldsymbol{q}_1, \dots, \boldsymbol{q}_r$ 若满足

$$\langle \boldsymbol{q}_i, \boldsymbol{q}_j \rangle = \delta_{i,j} = \begin{cases} 1, & i = j, \\ 0, & i \neq j, \end{cases}$$

即两两正交且长度都为 1，就称为标准正交组；它的 Gram 矩阵是 $\boldsymbol{I}_r$。张成子空间 U 的标准正交组称为 U 的**标准正交基**（orthonormal basis）；$U = V$ 时就是 V 的标准正交基。

在 $\mathbb{R}^m$ 中取欧氏内积，把 r 个向量排成 $\boldsymbol{Q} \in \mathbb{R}^{m\times r}$ 的各列，它们的 Gram 矩阵是 $\boldsymbol{Q}^{\top}\boldsymbol{Q}$，所以标准正交的条件就是 $\boldsymbol{Q}^{\top}\boldsymbol{Q} = \boldsymbol{I}_r$。$r = m$ 时，$\boldsymbol{Q}$ 是下面定义的正交矩阵。$r < m$ 时，$\boldsymbol{Q}^{\top}\boldsymbol{Q} = \boldsymbol{I}_r$ 仍成立，但 $\boldsymbol{Q}\boldsymbol{Q}^{\top}$ 的秩只有 r，不等于 $\boldsymbol{I}_m$，$\boldsymbol{Q}$ 只有左逆 $\boldsymbol{Q}^{\top}$。

标准正交组构成基 标准正交组总是线性无关。设 $\sum_j c_j \boldsymbol{q}_j = \boldsymbol{0}$，两边与 $\boldsymbol{q}_i$ 作内积。左边每一项 $c_j\langle \boldsymbol{q}_j, \boldsymbol{q}_i\rangle$ 只在 $j = i$ 时不为零，于是 $c_i = 0$；i 任意，所以全部系数为零。同样的论证说明两两正交的非零向量组线性无关，只是最后一步改为由 $c_i\langle \boldsymbol{q}_i, \boldsymbol{q}_i\rangle = 0$ 与 $\langle \boldsymbol{q}_i, \boldsymbol{q}_i\rangle > 0$ 得 $c_i = 0$。

因此标准正交组是它所张成子空间的一组基。在 d 维内积空间中，d 个两两正交的单位向量的个数等于维数，自动构成整个空间的标准正交基，不必另行验证张成。例如，$\mathbb{R}^d$ 的标准基在欧氏内积下是标准正交基；$\boldsymbol{q}_1 = (1,1)^{\top}/\sqrt{2}$、$\boldsymbol{q}_2 = (1,-1)^{\top}/\sqrt{2}$ 是 $\mathbb{R}^2$ 的另一组标准正交基。

标准正交基下的坐标 在标准正交基下，求坐标不必解方程。若 $\boldsymbol{v} = \sum_j c_j \boldsymbol{q}_j$，两边与 $\boldsymbol{q}_i$ 作内积，右边只剩 c_i 一项，所以

$$\boldsymbol{v} = \sum_{j=1}^{d} \langle \boldsymbol{v}, \boldsymbol{q}_j\rangle \boldsymbol{q}_j. \tag{3.13}$$

每个系数只与自己的方向有关，增加或删去其他方向都不改变它。坐标下的内积变成欧氏内积：$\langle \boldsymbol{v}, \boldsymbol{w} \rangle = \sum_j c_j d_j$，其中 c_j, d_j 分别是 $\boldsymbol{v}, \boldsymbol{w}$ 的坐标。特别地，

$$\|\boldsymbol{v}\|^2 = \sum_{j=1}^{d} \langle \boldsymbol{v}, \boldsymbol{q}_j \rangle^2, \tag{3.14}$$

即长度的平方等于各坐标的平方和。这称为 Parseval 恒等式，是勾股定理在 d 个互相垂直方向上的推广。下面用平面上的一组标准正交基验证这两点。

示例 3.61　标准正交基下的坐标与 Parseval 恒等式　取 $\mathbb{R}^2$ 的标准正交基 $\boldsymbol{q}_1 = (1,1)^{\mathsf{T}}/\sqrt{2}$、$\boldsymbol{q}_2 = (1,-1)^{\mathsf{T}}/\sqrt{2}$，求 $\boldsymbol{v} = (3,1)^{\mathsf{T}}$ 的坐标。按式 (3.13)，每个坐标就是一次内积：$\langle \boldsymbol{v}, \boldsymbol{q}_1 \rangle = 4/\sqrt{2} = 2\sqrt{2}$，$\langle \boldsymbol{v}, \boldsymbol{q}_2 \rangle = 2/\sqrt{2} = \sqrt{2}$，不必解方程。再核对 Parseval 恒等式：坐标的平方和为 $8 + 2 = 10$，与 $\|\boldsymbol{v}\|^2 = 3^2 + 1^2 = 10$ 相等。坐标换了，长度没有改变。

由 Parseval 恒等式，坐标的大小如实反映对象的大小，近共线基下“小对象、大系数”的现象不会发生。

正交矩阵　在 $\mathbb{R}^n$ 中，以一组标准正交基为列的方阵有专门的名称。若 n 阶方阵 $\boldsymbol{Q}$ 的各列都是单位向量，并且两两正交，就称它为**正交矩阵**（orthogonal matrix）。单位矩阵和置换矩阵都是正交矩阵，因为它们的列是互不相同的标准坐标向量。

下面检验平面旋转矩阵满足这一定义，并说明只有各列两两正交还不够。

示例 3.62　平面旋转是正交矩阵　对任一实数 ϕ，平面旋转矩阵为

$$\boldsymbol{R}_\phi = \begin{bmatrix} \cos\phi & -\sin\phi \\ \sin\phi & \cos\phi \end{bmatrix}.$$

按定义逐列检验。两列的长度都是 $\sqrt{\cos^2\phi + \sin^2\phi} = 1$，两列的内积为

$$\cos\phi \cdot (-\sin\phi) + \sin\phi \cdot \cos\phi = 0.$$

所以 $\boldsymbol{R}_\phi$ 是正交矩阵。作为对照，对角矩阵 $\mathrm{diag}(2,1)$ 的两列 $(2,0)^{\mathsf{T}}$ 与 $(0,1)^{\mathsf{T}}$ 内积为零，但第一列长度为 2。它的各列两两正交，却不是正交矩阵：定义还要求每列长度为 1。

逐列检验长度和内积比较繁琐。下面先把定义改写成一个矩阵等式，再由它推出正交矩阵的各项性质。

正交矩阵的转置条件　n 阶方阵 $\boldsymbol{Q}$ 是正交矩阵，当且仅当

$$\boldsymbol{Q}^{\top}\boldsymbol{Q}=\boldsymbol{I}_n.$$

这是因为 $(\boldsymbol{Q}^{\top}\boldsymbol{Q})_{i,j}$ 是 $\boldsymbol{Q}$ 的第 i 列与第 j 列的内积。“各列都是单位向量”对应对角元等于 1，“各列两两正交”对应非对角元等于 0，两者合起来正是这个矩阵等式。下面用这个条件重新检验示例 3.62中的两个矩阵。

示例 3.63　用转置条件检验正交矩阵　对旋转矩阵 $\boldsymbol{R}_{\phi}$ 与对角矩阵 $\operatorname{diag}(2,1)$，各算一次 $\boldsymbol{Q}^{\top}\boldsymbol{Q}$：

$$\begin{aligned}\boldsymbol{R}_{\phi}^{\top}\boldsymbol{R}_{\phi}&=\begin{bmatrix}\cos\phi & \sin\phi\\ -\sin\phi & \cos\phi\end{bmatrix}\begin{bmatrix}\cos\phi & -\sin\phi\\ \sin\phi & \cos\phi\end{bmatrix}\\&=\begin{bmatrix}\cos^2\phi+\sin^2\phi & 0\\ 0 & \sin^2\phi+\cos^2\phi\end{bmatrix}=\boldsymbol{I}_2,\end{aligned}$$

$$\operatorname{diag}(2,1)^{\top}\operatorname{diag}(2,1)=\operatorname{diag}(4,1)\neq\boldsymbol{I}_2.$$

$\boldsymbol{R}_{\phi}$ 满足转置条件，是正交矩阵。$\operatorname{diag}(2,1)$ 的乘积在 $(1,1)$ 位置为 $4\neq 1$，正好对应第一列长度不为 1；非对角元为零，对应两列正交。一次矩阵乘法同时完成了上例中逐列的全部检验。

正交矩阵保持内积　由内积中的转置与转置条件，

$$\langle\boldsymbol{Q}\boldsymbol{x},\boldsymbol{Q}\boldsymbol{y}\rangle=\langle\boldsymbol{x},\boldsymbol{Q}^{\top}\boldsymbol{Q}\boldsymbol{y}\rangle=\langle\boldsymbol{x},\boldsymbol{y}\rangle\qquad(\boldsymbol{Q}\text{为正交矩阵}).$$

特别地，正交矩阵把两两正交的向量仍送到两两正交的向量。

正交矩阵的乘法　若 $\boldsymbol{Q}_1,\boldsymbol{Q}_2$ 是 n 阶正交矩阵，则

$$(\boldsymbol{Q}_1\boldsymbol{Q}_2)^{\top}(\boldsymbol{Q}_1\boldsymbol{Q}_2)=\boldsymbol{Q}_2^{\top}\boldsymbol{Q}_1^{\top}\boldsymbol{Q}_1\boldsymbol{Q}_2=\boldsymbol{Q}_2^{\top}\boldsymbol{Q}_2=\boldsymbol{I}_n,$$

由转置条件，$\boldsymbol{Q}_1\boldsymbol{Q}_2$ 仍是正交矩阵。下面的例子显示，两个平面旋转的乘积不仅是正交矩阵，而且仍是旋转。

示例 3.64 两个平面旋转的乘积 把旋转矩阵 $\boldsymbol{R}_\phi$ 与 $\boldsymbol{R}_\psi$ 直接相乘，再用和角公式 $\cos(\phi+\psi)=\cos\phi\cos\psi-\sin\phi\sin\psi$ 与 $\sin(\phi+\psi)=\sin\phi\cos\psi+\cos\phi\sin\psi$，得

$$\begin{aligned}\boldsymbol{R}_\phi\boldsymbol{R}_\psi &= \begin{bmatrix}\cos\phi\cos\psi-\sin\phi\sin\psi & -\cos\phi\sin\psi-\sin\phi\cos\psi\\ \sin\phi\cos\psi+\cos\phi\sin\psi & -\sin\phi\sin\psi+\cos\phi\cos\psi\end{bmatrix}\\ &= \boldsymbol{R}_{\phi+\psi}.\end{aligned}$$

矩阵乘积 $\boldsymbol{R}_\phi\boldsymbol{R}_\psi$ 先作用 $\boldsymbol{R}_\psi$，所以这个等式说的是：先转 ψ 角、再转 ϕ 角，等于一次转 $\phi+\psi$ 角。乘积是正交矩阵，与上面的一般结论一致；这里还多知道一点，乘积仍是旋转。

正交矩阵的逆 正交矩阵求逆只需转置：

$$\boldsymbol{Q}^{-1}=\boldsymbol{Q}^{\mathsf{T}},$$
$$\boldsymbol{Q}\boldsymbol{Q}^{\mathsf{T}}=\boldsymbol{I}_n \qquad (\boldsymbol{Q}\text{为正交矩阵}).$$

转置条件 $\boldsymbol{Q}^{\mathsf{T}}\boldsymbol{Q}=\boldsymbol{I}_n$ 只说明 $\boldsymbol{Q}^{\mathsf{T}}$ 是 $\boldsymbol{Q}$ 的左逆。方阵只要有一侧的逆就可逆，而且这个单侧逆就是逆矩阵；这一点已在第 1.3.1.4节用行列式证明，第 2.3.3节又用核为零给出了另一个证明。由此 $\boldsymbol{Q}^{-1}=\boldsymbol{Q}^{\mathsf{T}}$，另一侧的乘积 $\boldsymbol{Q}\boldsymbol{Q}^{\mathsf{T}}$ 也等于 $\boldsymbol{I}_n$。

$\boldsymbol{Q}\boldsymbol{Q}^{\mathsf{T}}$ 的 (i,j) 元是 $\boldsymbol{Q}$ 的第 i 行与第 j 行的内积，所以正交矩阵的各行同样两两正交且长度为 1。又因 $(\boldsymbol{Q}^{\mathsf{T}})^{\mathsf{T}}\boldsymbol{Q}^{\mathsf{T}}=\boldsymbol{Q}\boldsymbol{Q}^{\mathsf{T}}=\boldsymbol{I}_n$，由转置条件，$\boldsymbol{Q}^{-1}=\boldsymbol{Q}^{\mathsf{T}}$ 也是正交矩阵。

正交矩阵的行列式 正交矩阵的行列式只能取两个值：

$$\det\boldsymbol{Q}=\pm1 \qquad (\boldsymbol{Q}\text{为正交矩阵}).$$

由 $\det(\boldsymbol{Q}^{\mathsf{T}})\det\boldsymbol{Q}=\det(\boldsymbol{Q}^{\mathsf{T}}\boldsymbol{Q})=\det\boldsymbol{I}_n=1$ 及 $\det(\boldsymbol{Q}^{\mathsf{T}})=\det\boldsymbol{Q}$，得 $(\det\boldsymbol{Q})^2=1$。旋转 $\boldsymbol{R}_\phi$ 的行列式为 $\cos^2\phi+\sin^2\phi=1$；交换两个坐标的置换矩阵行列式为 -1，它翻转了定向。

标准正交基之间的换基 正交矩阵也出现在标准正交基之间的换基中。设 $\mathcal{B}=(\boldsymbol{b}_1,\dots,\boldsymbol{b}_d)$ 与 $\mathcal{C}$ 都是 V 的标准正交基，换基矩阵 $\boldsymbol{S}=\boldsymbol{S}_{\mathcal{C}\leftarrow\mathcal{B}}$ 的第 j 列是 $\boldsymbol{b}_j$ 的 $\mathcal{C}$ 坐标。在标准正交基 $\mathcal{C}$ 下，内积就是坐标的欧氏内积，所以 $\boldsymbol{S}$ 的第 i、j 两列的欧氏内积等于 $\langle\boldsymbol{b}_i,\boldsymbol{b}_j\rangle=\delta_{i,j}$，即 $\boldsymbol{S}^{\mathsf{T}}\boldsymbol{S}=\boldsymbol{I}$。因此两组标准正交基之间的换基矩阵是正交矩阵。

于是反向换基只需转置，$\boldsymbol{S}^{-1}=\boldsymbol{S}^{\top}$，不会出现示例 2.18中除以小数 ε 的放大。例如从上面的 $(\boldsymbol{q}_1,\boldsymbol{q}_2)$ 换到标准基，换基矩阵的两列就是 $\boldsymbol{q}_1,\boldsymbol{q}_2$ 本身。对线性算子，若只在标准正交基之间换基，相似关系 $\boldsymbol{B}=\boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P}$ 变成 $\boldsymbol{B}=\boldsymbol{P}^{\top}\boldsymbol{A}\boldsymbol{P}$。第 4章的谱定理就是在这种受限的换基下化简对称矩阵。

正交不变性 正交矩阵保持欧氏长度，因此也不改变与欧氏长度相关的矩阵范数。设 $\boldsymbol{Q}$ 为正交矩阵，则

$$\|\boldsymbol{Q}\boldsymbol{x}\|_2=\|\boldsymbol{x}\|_2,$$
$$\|\boldsymbol{Q}\|_2=1,$$

$$\|\boldsymbol{Q}\boldsymbol{A}\|_{\mathrm{F}}=\|\boldsymbol{A}\|_{\mathrm{F}},$$
$$\|\boldsymbol{Q}\boldsymbol{A}\|_2=\|\boldsymbol{A}\|_2.$$

由 $\|\boldsymbol{Q}\boldsymbol{x}\|_2^2=\boldsymbol{x}^{\top}\boldsymbol{Q}^{\top}\boldsymbol{Q}\boldsymbol{x}=\|\boldsymbol{x}\|_2^2$，正交矩阵保持欧氏长度，所以每个比值 $\|\boldsymbol{Q}\boldsymbol{x}\|_2/\|\boldsymbol{x}\|_2$ 都等于 1，$\|\boldsymbol{Q}\|_2=1$。对矩阵 $\boldsymbol{A}$，左乘 $\boldsymbol{Q}$ 不改变各列的长度，$\|\boldsymbol{Q}\boldsymbol{A}_{:,j}\|_2=\|\boldsymbol{A}_{:,j}\|_2$，对 j 求平方和即得 $\|\boldsymbol{Q}\boldsymbol{A}\|_{\mathrm{F}}=\|\boldsymbol{A}\|_{\mathrm{F}}$。左乘 $\boldsymbol{Q}$ 也不改变每个输出的长度，$\|\boldsymbol{Q}\boldsymbol{A}\boldsymbol{x}\|_2=\|\boldsymbol{A}\boldsymbol{x}\|_2$，取上确界即得 $\|\boldsymbol{Q}\boldsymbol{A}\|_2=\|\boldsymbol{A}\|_2$。

3.5.3 Gram–Schmidt 正交化

本小节说明，任意一组线性无关的向量都可以改造成标准正交组。思路来自正交分解：依次处理各向量，从每个向量中扣除它在已经得到的方向上的分量，剩下的部分与这些方向都垂直，再把它缩放到单位长度。下面先给出这一过程并证明它总能完成，再把它在 $\mathbb{R}^m$ 中写成矩阵分解，最后处理各列线性相关的情形。

3.5.3.1 Gram–Schmidt 正交化

这一过程称为Gram–Schmidt 正交化（Gram–Schmidt orthogonalization），也称施密特正交化。设 $\boldsymbol{v}_1,\dots,\boldsymbol{v}_k$ 线性无关。令 $\boldsymbol{u}_1=\boldsymbol{v}_1$、$\boldsymbol{q}_1=\boldsymbol{u}_1/\|\boldsymbol{u}_1\|$；对 $j=2,\dots,k$ 依次令

$$\begin{aligned}\boldsymbol{u}_j&=\boldsymbol{v}_j-\sum_{i=1}^{j-1}\langle\boldsymbol{v}_j,\boldsymbol{q}_i\rangle\boldsymbol{q}_i,\\ \boldsymbol{q}_j&=\frac{\boldsymbol{u}_j}{\|\boldsymbol{u}_j\|}.\end{aligned}\tag{3.15}$$

扣除的部分在 $\operatorname{span}\{\boldsymbol{q}_1,\dots,\boldsymbol{q}_{j-1}\}$ 中，剩下的 $\boldsymbol{u}_j$ 与这些方向都正交，所以 $\boldsymbol{u}_j$ 正是正交分解中的剩余分量。下面的定理验证这一点，并说明过程不会中断。

定理 3.65 Gram–Schmidt 正交化 上述过程中每个 $\boldsymbol{u}_j \neq \mathbf{0}$，得到的 $\boldsymbol{q}_1, \dots, \boldsymbol{q}_k$ 两两正交、长度为 1，并且对每个 j 都有 $\operatorname{span}\{\boldsymbol{q}_1, \dots, \boldsymbol{q}_j\} = \operatorname{span}\{\boldsymbol{v}_1, \dots, \boldsymbol{v}_j\}$。

证明 对 j 归纳。$j = 1$ 时 $\boldsymbol{u}_1 = \boldsymbol{v}_1 \neq \mathbf{0}$，结论成立。设结论对 $j-1$ 成立。对 $i < j$，由 $\boldsymbol{q}_1, \dots, \boldsymbol{q}_{j-1}$ 两两正交且长度为 1，

$$\langle \boldsymbol{u}_j, \boldsymbol{q}_i \rangle = \langle \boldsymbol{v}_j, \boldsymbol{q}_i \rangle - \langle \boldsymbol{v}_j, \boldsymbol{q}_i \rangle \langle \boldsymbol{q}_i, \boldsymbol{q}_i \rangle = 0,$$

所以 $\boldsymbol{u}_j$ 与前面的方向都正交。若 $\boldsymbol{u}_j = \mathbf{0}$，则 $\boldsymbol{v}_j$ 落在前 $j-1$ 个新方向的张成空间中。由归纳假设，这也是前 $j-1$ 个原向量的张成空间，与线性无关矛盾；故 $\boldsymbol{u}_j \neq \mathbf{0}$，$\boldsymbol{q}_j$ 有定义且长度为 1。最后，$\boldsymbol{q}_j$ 是 $\boldsymbol{v}_j$ 与 $\boldsymbol{q}_1, \dots, \boldsymbol{q}_{j-1}$ 的组合，因而属于 $\operatorname{span}\{\boldsymbol{v}_1, \dots, \boldsymbol{v}_j\}$；反过来，由式 (3.15)，$\boldsymbol{v}_j = \|\boldsymbol{u}_j\| \boldsymbol{q}_j + \sum_{i<j} \langle \boldsymbol{v}_j, \boldsymbol{q}_i \rangle \boldsymbol{q}_i$ 属于 $\operatorname{span}\{\boldsymbol{q}_1, \dots, \boldsymbol{q}_j\}$。两个张成空间互相包含，因而相等。 ■

对有限维内积空间的任意一组基作 Gram–Schmidt 正交化，就得到一组标准正交基，所以每个有限维内积空间都有标准正交基。若已有几个两两正交的单位向量，可以先把它们扩充成一组基，再从它们之后开始正交化。前面的向量在过程中保持不变，所以任何标准正交组都能扩充成标准正交基。

张成空间逐段相等也有用处：前 j 个新方向与前 j 个旧方向张成同一个子空间，正交化只是在每一段内部换了一组更好用的基。

算例 标准正交基依赖内积；换一个内积，同一组基正交化的结果也不同。下面在示例 3.41的内积下对基 $(1, t)$ 作正交化。在这个内积下 $\langle 1, t \rangle = 1 \neq 0$，两个基向量并不正交。

示例 3.66 两点内积下的 Gram–Schmidt 正交化 在 P_1 的内积 $\langle f, g \rangle = f(0)g(0) + f(1)g(1)$ 下，对基 $(1, t)$ 逐步执行式 (3.15)。这个内积只看 $t = 0, 1$ 两处的取值，所以每次计算内积或长度，都先写出函数在这两点的值。

先归一化第一个基向量。常数 1 在两点都取 1，$\|1\|^2 = 1^2 + 1^2 = 2$，所以

$$q_1 = \frac{1}{\sqrt{2}}.$$

再从 t 中扣除它在 q_1 上的分量。t 在两点取值 $0,1$，$\langle t,q_1\rangle=(0\cdot1+1\cdot1)/\sqrt{2}=1/\sqrt{2}$，所以

$$u_2=t-\langle t,q_1\rangle q_1=t-\frac{1}{\sqrt{2}}\cdot\frac{1}{\sqrt{2}}=t-\frac{1}{2}.$$

扣除的常数 $\frac{1}{2}$ 正是 t 在两点取值的平均。最后归一化：u_2 在 $t=0,1$ 处的取值为 $-\frac{1}{2},\frac{1}{2}$，$\|u_2\|^2=\frac{1}{4}+\frac{1}{4}=\frac{1}{2}$，于是

$$q_2=\frac{u_2}{\|u_2\|}=\sqrt{2}\Big(t-\frac{1}{2}\Big).$$

可以核对结果确实标准正交。q_1 在 $t=0,1$ 处取值都是 $\frac{1}{\sqrt{2}}$，q_2 取值为 $-\frac{\sqrt{2}}{2},\frac{\sqrt{2}}{2}$，所以 $\langle q_1,q_2\rangle=\frac{1}{\sqrt{2}}\cdot(-\frac{\sqrt{2}}{2})+\frac{1}{\sqrt{2}}\cdot\frac{\sqrt{2}}{2}=0$，$\|q_2\|^2=\frac{1}{2}+\frac{1}{2}=1$。

有了标准正交基，坐标就由内积直接读出。$f=1+t$ 在 $t=0,1$ 处取值为 $1,2$，所以 $\langle f,q_1\rangle=(1+2)/\sqrt{2}=3/\sqrt{2}$，$\langle f,q_2\rangle=1\cdot(-\frac{\sqrt{2}}{2})+2\cdot\frac{\sqrt{2}}{2}=\frac{\sqrt{2}}{2}$。用这两个坐标还原，得 $\frac{3}{\sqrt{2}}\cdot\frac{1}{\sqrt{2}}+\frac{\sqrt{2}}{2}\cdot\sqrt{2}(t-\frac{1}{2})=\frac{3}{2}+t-\frac{1}{2}=1+t$；Parseval 恒等式也成立：$\|f\|^2=1^2+2^2=5$，而 $\frac{9}{2}+\frac{1}{2}=5$。所以 $q_1=1/\sqrt{2}$、$q_2=\sqrt{2}(t-\frac{1}{2})$ 是这一内积下 P_1 的标准正交基，$1+t$ 在其下的坐标为 $(3/\sqrt{2},\ \sqrt{2}/2)$。

正交化把 t 换成了 $t-\frac{1}{2}$。在系数向量的欧氏内积下，1 与 t 的系数列 $(1,0)^{\mathsf T}$、$(0,1)^{\mathsf T}$ 本来就正交；换了内积以后，才需要这一步。

3.5.3.2 QR 分解

在 $\mathbb{R}^m$ 中取欧氏内积，Gram–Schmidt 正交化可以写成一个矩阵等式。它把一组列向量的方向与组合系数分开记录。

设 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$ 的列 $\boldsymbol{a}_1,\dots,\boldsymbol{a}_d$ 线性无关，对它们作正交化，即取 $\boldsymbol{v}_j=\boldsymbol{a}_j$。把式 (3.15)反过来写，得 $\boldsymbol{a}_j=\|\boldsymbol{u}_j\|\boldsymbol{q}_j+\sum_{i<j}\langle\boldsymbol{a}_j,\boldsymbol{q}_i\rangle\boldsymbol{q}_i$。所以每一列只用到前 j 个正交方向：

$$\boldsymbol{a}_j=\sum_{i\le j}r_{i,j}\boldsymbol{q}_i,\qquad r_{i,j}=\langle\boldsymbol{a}_j,\boldsymbol{q}_i\rangle\ (i<j),\qquad r_{j,j}=\|\boldsymbol{u}_j\|>0.$$

把 $\boldsymbol{q}_1,\dots,\boldsymbol{q}_d$ 排成 $\boldsymbol{Q}\in\mathbb{R}^{m\times d}$，把系数 $r_{i,j}$ 排成 d 阶上三角矩阵 $\boldsymbol{R}$（$i>j$ 时 $r_{i,j}=0$）。按矩阵乘积的列读法，各列的这些关系合写为经济型QR 分解（QR factorization）

$$\boldsymbol{A}=\boldsymbol{Q}\boldsymbol{R},\qquad \boldsymbol{Q}^{\mathsf T}\boldsymbol{Q}=\boldsymbol{I}_d,\qquad \boldsymbol{R}\text{ 上三角且对角元为正.}\tag{3.16}$$

由定理 3.65，$\boldsymbol{Q}$ 的列是列空间 range($\boldsymbol{A}$) 的标准正交基，$\boldsymbol{R}$ 的第 j 列记录 $\boldsymbol{a}_j$ 在这组正交方向上的坐标。$\boldsymbol{R}$ 的对角元为正，所以 $\boldsymbol{R}$ 可逆。图 3.6给出最小的二维情形：保留第一个单位方向，从第二列减去它在第一个方向上的分量，列空间不变，减去的部分记进 $\boldsymbol{R}$。

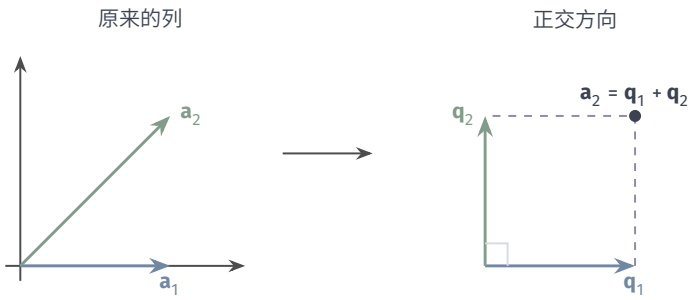


图 3.6　QR 分解把列的方向和组合系数分开。取 $\boldsymbol{a}_1 = (1,0)^{\mathsf{T}}$、$\boldsymbol{a}_2 = (1,1)^{\mathsf{T}}$，正交化得到 $\boldsymbol{q}_1 = (1,0)^{\mathsf{T}}$、$\boldsymbol{q}_2 = (0,1)^{\mathsf{T}}$，并有 $\boldsymbol{a}_1 = \boldsymbol{q}_1$、$\boldsymbol{a}_2 = \boldsymbol{q}_1 + \boldsymbol{q}_2$，故 $\boldsymbol{R} = \left[\begin{smallmatrix} 1 & 1 \\ 0 & 1 \end{smallmatrix}\right]$。虚线补出第二列的分量。

这一分解的用处在于，涉及列空间的计算可以改在标准正交的 $\boldsymbol{Q}$ 上进行，坐标由内积直接读出，不必再解 Gram 方程。第 9章与第 10章解方程与最小二乘问题时就是这样使用它的。

3.5.3.3 列相关时的处理

定理 3.65要求各列线性无关。若不满足，某一步会出现 $\boldsymbol{u}_j = \boldsymbol{0}$。由正交分解，这恰好说明 $\boldsymbol{a}_j$ 已在前面方向张成的空间中，没有带来新方向。这时不能对零向量归一化，应跳过这一列，只在 $\boldsymbol{R}$ 中记下它的系数 $\langle \boldsymbol{a}_j, \boldsymbol{q}_i \rangle$。跳过它不影响后续各列，因为张成的空间没有变。

全部处理完以后，留下的 $\boldsymbol{q}$ 的个数等于列空间的维数 $r = \operatorname{rank} \boldsymbol{A}$，仍有 $\boldsymbol{A} = \boldsymbol{Q}\boldsymbol{R}$。其中 $\boldsymbol{Q} \in \mathbb{R}^{m \times r}$ 的列是列空间的标准正交基；$\boldsymbol{R} \in \mathbb{R}^{r \times d}$ 各行从左到右第一个非零元的位置逐行右移。$r < d$ 时 $\boldsymbol{R}$ 不是方阵，不能求逆。下面是最小的例子。

示例 3.67　列相关时跳过零余量　设 $\boldsymbol{A} = [\boldsymbol{a}_1\ \boldsymbol{a}_2]$，其中 $\boldsymbol{a}_1 = (1,0)^{\mathsf{T}}$、$\boldsymbol{a}_2 = (2,0)^{\mathsf{T}}$，第二列是第一列的两倍。$\boldsymbol{a}_1$ 已是单位向量，$\boldsymbol{q}_1 = \boldsymbol{a}_1$。

处理第二列时，$\langle \boldsymbol{a}_2, \boldsymbol{q}_1 \rangle = 2$，扣除后 $\boldsymbol{u}_2 = \boldsymbol{a}_2 - 2\boldsymbol{q}_1 = \boldsymbol{0}$：第二列没有带来新方向。于是跳过 $\boldsymbol{a}_2$，只在 $\boldsymbol{R}$ 中记下系数 2，得到 $r = 1$，

$$\boldsymbol{Q} = \begin{bmatrix} 1 \\ 0 \end{bmatrix},$$
$$\boldsymbol{R} = \begin{bmatrix} 1 & 2 \end{bmatrix},$$
$$\boldsymbol{Q}\boldsymbol{R} = \begin{bmatrix} 1 & 2 \\ 0 & 0 \end{bmatrix} = \boldsymbol{A}.$$

乘回去仍得到 $\boldsymbol{A}$，说明跳过的列并没有丢失信息，它的系数保存在 $\boldsymbol{R}$ 中。列空间是 x 轴，$\boldsymbol{Q}$ 的唯一一列构成它的标准正交基，留下的列数 1 正是 $\operatorname{rank} \boldsymbol{A}$；$\boldsymbol{R}$ 是 1×2 矩阵，不能求逆。

于是在精确算术下，同一过程也给出列空间的一组标准正交基与矩阵的秩。有限精度下，扣除后的余量很少恰好为零；怎样判断它“算作零”，以及怎样改写扣除顺序以减少正交性的损失，属于数值计算问题，在第 14.1节讨论。

3.5.4 正交投影

标准正交基使子空间中的分量可以逐个读出。把这些分量合在一起，就得到正交投影。本小节证明它是子空间中离原向量最近的点，再把它写成矩阵，并给出判断一个矩阵是否为正交投影的方法。

向子空间的正交分解　若 $\boldsymbol{q}_1, \dots, \boldsymbol{q}_r$ 是子空间 U 的标准正交基，引理 3.58中的 Gram 矩阵是单位矩阵，Gram 方程直接给出 $\boldsymbol{a} = (\langle \boldsymbol{q}_i, \boldsymbol{x} \rangle)_i$。于是分解可以直接写出：

$$\boldsymbol{x} = \underbrace{\sum_{j=1}^{r} \langle \boldsymbol{x}, \boldsymbol{q}_j \rangle \boldsymbol{q}_j}_{\boldsymbol{u} \in U} + \underbrace{\Big(\boldsymbol{x} - \sum_{j=1}^{r} \langle \boldsymbol{x}, \boldsymbol{q}_j \rangle \boldsymbol{q}_j \Big)}_{\boldsymbol{r} \in U^{\perp}}. \tag{3.17}$$

$\boldsymbol{u}$ 称为 $\boldsymbol{x}$ 在 U 上的正交投影。$\boldsymbol{u}$ 与 $\boldsymbol{r}$ 正交，由勾股定理，

$$\|\boldsymbol{x}\|^2 = \|\boldsymbol{u}\|^2 + \|\boldsymbol{r}\|^2 \geq \sum_{j=1}^{r} \langle \boldsymbol{x}, \boldsymbol{q}_j \rangle^2.$$

即沿一部分标准正交方向读出的系数，其平方和不超过总长度的平方；等号恰在 $\boldsymbol{x} \in U$ 时成立。

现在证明 $\boldsymbol{u}$ 是最近点。对任意 $\boldsymbol{v}\in U$，$\boldsymbol{x}-\boldsymbol{v}=(\boldsymbol{x}-\boldsymbol{u})+(\boldsymbol{u}-\boldsymbol{v})$ 的两项分别属于 $U^{\perp}$ 和 U。由勾股定理，

$$\|\boldsymbol{x}-\boldsymbol{v}\|^2=\|\boldsymbol{x}-\boldsymbol{u}\|^2+\|\boldsymbol{u}-\boldsymbol{v}\|^2\geq\|\boldsymbol{x}-\boldsymbol{u}\|^2.$$

等号只在 $\boldsymbol{v}=\boldsymbol{u}$ 时成立，所以 $\boldsymbol{u}$ 是唯一的最近点。基不是标准正交时，同样可以先解 Gram 方程求出投影；实际求解时不必显式形成逆矩阵。

最近点的唯一性来自内积确定的正交分解。第 3.3.6节已经证明一般范数下最近点存在，示例 3.39却在 ℓ_∞ 范数下给出了无穷多个最近点；同一个点在欧氏范数下的最近点只有原点，因为 $\|\boldsymbol{y}-(t,0)^{\top}\|_2^2=t^2+1$ 只在 $t=0$ 时取最小值。

下面用标准正交基重算前面的正交分解。

示例 3.68　用标准正交基重算正交分解　回到示例 3.59的 $\boldsymbol{y}=(1,1.1,0.9)^{\top}$ 与直线 U，这次先把方向向量归一化为 $\boldsymbol{q}_1=(1,1,1)^{\top}/\sqrt{3}$，于是 $U=\operatorname{span}\{\boldsymbol{q}_1\}$。投影系数就是一次内积 $\langle\boldsymbol{y},\boldsymbol{q}_1\rangle=3/\sqrt{3}=\sqrt{3}$，投影为 $\sqrt{3}\,\boldsymbol{q}_1=(1,1,1)^{\top}$，余量为 $(0,0.1,-0.1)^{\top}$，它与 $\boldsymbol{q}_1$ 正交。结果与前例相同，但这里不需要解 Gram 方程：归一化已经把 Gram 矩阵变成了 1。由上面的最近点性质，$(1,1,1)^{\top}$ 还是直线 U 上离 $\boldsymbol{y}$ 最近的点。

投影矩阵　正交投影随原向量线性变化。记 $\boldsymbol{y}$ 在 U 上的正交投影为 $\boldsymbol{p}$。$\boldsymbol{y}_1,\boldsymbol{y}_2$ 的正交分解相加、数乘后仍是正交分解，由分解的唯一性，投影也随之相加、数乘。所以 $\boldsymbol{y}\mapsto\boldsymbol{p}$ 是一个线性映射，称为到 U 的正交投影。

在欧氏内积下，它可以写成矩阵。设 $\boldsymbol{Q}$ 的列是 U 的标准正交基。由 $\boldsymbol{p}=\sum_j\langle\boldsymbol{q}_j,\boldsymbol{y}\rangle\boldsymbol{q}_j=\boldsymbol{Q}\boldsymbol{Q}^{\top}\boldsymbol{y}$，到 U 的正交投影是

$$\begin{aligned}\boldsymbol{P}_U&=\boldsymbol{Q}\boldsymbol{Q}^{\top},\\ \boldsymbol{P}_U^{\top}&=\boldsymbol{P}_U,\\ \boldsymbol{P}_U^2&=\boldsymbol{P}_U.\end{aligned}\tag{3.18}$$

两条性质都可以直接验证。由 $\boldsymbol{Q}^{\top}\boldsymbol{Q}=\boldsymbol{I}$，$\boldsymbol{P}_U^2=\boldsymbol{Q}(\boldsymbol{Q}^{\top}\boldsymbol{Q})\boldsymbol{Q}^{\top}=\boldsymbol{Q}\boldsymbol{Q}^{\top}$，即幂等：已经在 U 中的点再投影一次不变。$(\boldsymbol{Q}\boldsymbol{Q}^{\top})^{\top}=\boldsymbol{Q}\boldsymbol{Q}^{\top}$，即对称：内积中可以把投影移到另一侧。此外 $\operatorname{range}\boldsymbol{P}_U=\operatorname{range}\boldsymbol{Q}=U$。$\boldsymbol{Q}$ 不是方阵时，$\boldsymbol{P}_U$ 通常不是单位矩阵，它只保留 U 中的分量。

正交投影、斜投影与幂等　拿到一个矩阵，怎样判断它是不是正交投影？幂等性只说明它是某种投影，不说明它给出最近点。一般的幂等矩阵 $\boldsymbol{P}$ 把 $\boldsymbol{y}$ 分成 $\boldsymbol{P}\boldsymbol{y}$ 与 $\boldsymbol{y}-\boldsymbol{P}\boldsymbol{y}$ 两部分，前者在像中，后者在零空间中，因为

$\boldsymbol{P}(\boldsymbol{y}-\boldsymbol{P}\boldsymbol{y})=\boldsymbol{P}\boldsymbol{y}-\boldsymbol{P}^2\boldsymbol{y}=\boldsymbol{0}$。但两部分不必正交。这种映射称为**斜投影**（oblique projection）。

示例 3.69　反例：幂等而不对称的投影　取

$$\boldsymbol{P}=\begin{bmatrix}1 & -1\\ 0 & 0\end{bmatrix}.$$

直接相乘得 $\boldsymbol{P}^2=\boldsymbol{P}$，所以它幂等；它把 $(y_1,y_2)^{\mathsf{T}}$ 送到 x 轴上的 $(y_1-y_2,0)^{\mathsf{T}}$。残差 $\boldsymbol{y}-\boldsymbol{P}\boldsymbol{y}=(y_2,y_2)^{\mathsf{T}}$ 与 x 轴方向 $(1,0)^{\mathsf{T}}$ 的内积是 y_2，$y_2\neq 0$ 时不为零，所以 $\boldsymbol{P}\boldsymbol{y}$ 不是 x 轴上离 $\boldsymbol{y}$ 最近的点。这个 $\boldsymbol{P}$ 也不对称：$\boldsymbol{P}^{\mathsf{T}}\neq\boldsymbol{P}$。

对称性正是正交的条件。若 $\boldsymbol{P}$ 幂等且对称，对任意 $\boldsymbol{y},\boldsymbol{z}$ 有

$$(\boldsymbol{y}-\boldsymbol{P}\boldsymbol{y})^{\mathsf{T}}\boldsymbol{P}\boldsymbol{z}=\boldsymbol{y}^{\mathsf{T}}(\boldsymbol{P}-\boldsymbol{P}^{\mathsf{T}}\boldsymbol{P})\boldsymbol{z}=\boldsymbol{y}^{\mathsf{T}}(\boldsymbol{P}-\boldsymbol{P}^2)\boldsymbol{z}=0,$$

即残差与整个像正交。于是 $\boldsymbol{y}=\boldsymbol{P}\boldsymbol{y}+(\boldsymbol{y}-\boldsymbol{P}\boldsymbol{y})$ 是 $\boldsymbol{y}$ 关于像空间的正交分解，由分解的唯一性，$\boldsymbol{P}$ 就是到其像的正交投影。所以判别分两步：先验幂等，判断是不是投影；再验对称，判断是不是正交投影。

3.6　线性泛函的内积表示与伴随

第 2.4节的读取规则属于对偶空间，与被读取的向量不在同一个空间；转置在那里是对偶映射的矩阵。有了内积，每个读取都可以写成与一个固定向量的内积，对偶映射也就变成内积空间之间的映射，称为伴随。第 3.5.1节证明四个基本子空间的正交关系时，用到的正是伴随在欧氏内积下的形式：内积左侧的 $\boldsymbol{A}$ 可以改写成右侧的 $\boldsymbol{A}^{\mathsf{T}}$。

3.6.1　线性泛函的内积表示

在 $\mathbb{R}^d$ 的欧氏内积下，加权读取 $\varphi(\boldsymbol{x})=\boldsymbol{a}^{\mathsf{T}}\boldsymbol{x}$ 就是与向量 $\boldsymbol{a}$ 的内积。在一般有限维内积空间中，每个读取也都能这样写。

定理 3.70　有限维 Riesz 表示定理　设 V 是有限维内积空间。对每个 $\varphi\in V^*$，存在唯一的 $\boldsymbol{v}_\varphi\in V$，使 $\varphi(\boldsymbol{x})=\langle\boldsymbol{x},\boldsymbol{v}_\varphi\rangle$ 对所有 $\boldsymbol{x}\in V$ 成立。

证明 取 V 的一组标准正交基 $\boldsymbol{q}_1,\dots,\boldsymbol{q}_d$（第 3.5.3节），令 $\boldsymbol{v}_\varphi = \sum_j \varphi(\boldsymbol{q}_j)\boldsymbol{q}_j$。由式 (3.13)，$\boldsymbol{x} = \sum_j \langle \boldsymbol{x}, \boldsymbol{q}_j\rangle \boldsymbol{q}_j$，于是

$$\varphi(\boldsymbol{x}) = \sum_j \langle \boldsymbol{x}, \boldsymbol{q}_j\rangle \varphi(\boldsymbol{q}_j) = \Big\langle \boldsymbol{x}, \sum_j \varphi(\boldsymbol{q}_j)\boldsymbol{q}_j \Big\rangle = \langle \boldsymbol{x}, \boldsymbol{v}_\varphi\rangle.$$

若 $\boldsymbol{v}, \boldsymbol{v}'$ 都满足要求，则 $\langle \boldsymbol{x}, \boldsymbol{v}-\boldsymbol{v}'\rangle = 0$ 对一切 $\boldsymbol{x}$ 成立，取 $\boldsymbol{x} = \boldsymbol{v}-\boldsymbol{v}'$ 得 $\boldsymbol{v} = \boldsymbol{v}'$。 ■

对应 $\varphi \mapsto \boldsymbol{v}_\varphi$ 保持线性组合，这由表示向量的唯一性得到；每个 $\boldsymbol{v}$ 又都表示读取 $\langle \cdot, \boldsymbol{v}\rangle$。所以这个对应是 V^* 到 V 的双射。在它之下，标准正交基的对偶基就是这组基本身，因为第 j 个坐标读取是 $\boldsymbol{x} \mapsto \langle \boldsymbol{x}, \boldsymbol{q}_j\rangle$。对一般的基，对偶基对应的向量与原基不同：图 2.11中的红色箭头 $\boldsymbol{b}^1, \boldsymbol{b}^2$，正是对偶读取 φ_1, φ_2 在欧氏内积下对应的向量。

表示向量依赖内积，读取本身却不依赖。在 $\mathbb{R}^d$ 上取加权内积 $\langle \boldsymbol{x}, \boldsymbol{y}\rangle_{\boldsymbol{M}} = \boldsymbol{x}^{\top}\boldsymbol{M}\boldsymbol{y}$，同一个读取 $\varphi(\boldsymbol{x}) = \boldsymbol{a}^{\top}\boldsymbol{x} = \boldsymbol{x}^{\top}\boldsymbol{M}(\boldsymbol{M}^{-1}\boldsymbol{a})$ 对应的向量是 $\boldsymbol{M}^{-1}\boldsymbol{a}$，而不是 $\boldsymbol{a}$。函数空间中也是如此。

示例 3.71 积分读取在两点内积下的表示向量 在 P_1 上取两点内积 $\langle f, g\rangle = f(0)g(0) + f(1)g(1)$，考虑积分读取 $\varphi(f) = \int_0^1 f(t)\,\mathrm{d}t$。对 $f = a + bt$，$\varphi(f) = a + b/2$。要把它写成与某个固定函数的内积，而这个内积只用到 $f(0) = a$ 与 $f(1) = a+b$，所以先把 $a + b/2$ 表示成这两个值的组合：$a + b/2 = \frac{1}{2}\big(f(0) + f(1)\big)$。这正是 f 与常数函数 $\frac{1}{2}$ 的内积：

$$\Big\langle f, \tfrac{1}{2}\Big\rangle = \tfrac{1}{2}\big(f(0)+f(1)\big) = \tfrac{1}{2}(a + a + b) = a + \frac{b}{2}.$$

因此 $\boldsymbol{v}_\varphi$ 是常数函数 $\frac{1}{2}$。在系数向量的欧氏内积下，同一个读取对应 $(1, 1/2)^{\top}$，表示向量随内积而变。等式 $\varphi(f) = \frac{1}{2}\big(f(0)+f(1)\big)$ 也说明梯形公式对一次函数精确。

表示向量还给出读取的大小。由 Cauchy–Schwarz 不等式，$|\varphi(\boldsymbol{x})| \le \|\boldsymbol{x}\|\,\|\boldsymbol{v}_\varphi\|$；$\boldsymbol{v}_\varphi \neq \boldsymbol{0}$ 时，取 $\boldsymbol{x} = \boldsymbol{v}_\varphi/\|\boldsymbol{v}_\varphi\|$ 可取到等号。所以仿照第 3.3.5节，在单位球上取读取的最大值，得到

$$\|\varphi\|_* = \max_{\|\boldsymbol{x}\|\le 1} |\varphi(\boldsymbol{x})| = \|\boldsymbol{v}_\varphi\|.$$

在 $\mathbb{R}^d$ 的欧氏内积下，这就是 ℓ_2 范数的对偶范数仍为 ℓ_2 范数。

3.6.2 伴随与特殊线性算子

对偶映射把输出端的读取 f 传回输入端，得到读取 $f\circ T$。若把两端的读取都换成表示它的向量，就得到伴随。

定义 3.72 伴随 设 $T:V\to W$ 是两个有限维实内积空间之间的线性映射。若存在 $T^\star:W\to V$ 使

$$\langle T\boldsymbol{x},\boldsymbol{y}\rangle_W=\langle \boldsymbol{x},T^\star\boldsymbol{y}\rangle_V \tag{3.19}$$

对所有 $\boldsymbol{x}\in V$、$\boldsymbol{y}\in W$ 成立，则 $T^\star$ 称为 T 的**伴随**（adjoint）。

伴随总存在且唯一。固定 $\boldsymbol{y}\in W$，$\boldsymbol{x}\mapsto\langle T\boldsymbol{x},\boldsymbol{y}\rangle_W$ 是 V 上的线性泛函。由定理 3.70，存在唯一的向量使它写成与该向量的内积，把这个向量记为 $T^\star\boldsymbol{y}$。$T^\star$ 对 $\boldsymbol{y}$ 线性：

$$\langle \boldsymbol{x},aT^\star\boldsymbol{y}+bT^\star\boldsymbol{y}'\rangle_V=a\langle T\boldsymbol{x},\boldsymbol{y}\rangle_W+b\langle T\boldsymbol{x},\boldsymbol{y}'\rangle_W=\langle T\boldsymbol{x},a\boldsymbol{y}+b\boldsymbol{y}'\rangle_W,$$

由表示向量的唯一性，$T^\star(a\boldsymbol{y}+b\boldsymbol{y}')=aT^\star\boldsymbol{y}+bT^\star\boldsymbol{y}'$。

用对偶映射的语言说，把 $\boldsymbol{y}\in W$ 看成读取 $\langle\cdot,\boldsymbol{y}\rangle_W$，则 T' 把它送到读取 $\langle T\,\cdot,\boldsymbol{y}\rangle_W=\langle\cdot,T^\star\boldsymbol{y}\rangle_V$。所以伴随就是借内积把读取换成向量以后的对偶映射。

具体计算时，取 V,W 的基。由坐标下的内积公式，两边的内积写成 $\langle\boldsymbol{x},\boldsymbol{x}'\rangle_V=\boldsymbol{x}^{\mathsf T}\boldsymbol{M}_V\boldsymbol{x}'$、$\langle\boldsymbol{y},\boldsymbol{y}'\rangle_W=\boldsymbol{y}^{\mathsf T}\boldsymbol{M}_W\boldsymbol{y}'$，这里 $\boldsymbol{x},\boldsymbol{y}$ 等指坐标，$\boldsymbol{M}_V,\boldsymbol{M}_W$ 是两组基的 Gram 矩阵，对称正定因而可逆。设 T 的矩阵为 $\boldsymbol{A}$，伴随的矩阵为 $\boldsymbol{B}$。式 (3.19)要求 $(\boldsymbol{A}\boldsymbol{x})^{\mathsf T}\boldsymbol{M}_W\boldsymbol{y}=\boldsymbol{x}^{\mathsf T}\boldsymbol{M}_V\boldsymbol{B}\boldsymbol{y}$ 对所有 $\boldsymbol{x},\boldsymbol{y}$ 成立。取 $\boldsymbol{x},\boldsymbol{y}$ 为标准坐标向量逐个比较元素，这等价于 $\boldsymbol{A}^{\mathsf T}\boldsymbol{M}_W=\boldsymbol{M}_V\boldsymbol{B}$，即

$$\boldsymbol{B}=\boldsymbol{M}_V^{-1}\boldsymbol{A}^{\mathsf T}\boldsymbol{M}_W. \tag{3.20}$$

两端都取标准正交基时，$\boldsymbol{M}_V,\boldsymbol{M}_W$ 都是单位矩阵，伴随矩阵就是 $\boldsymbol{A}^{\mathsf T}$，与对偶映射的矩阵相同。一般情形下，伴随既不是单纯转置，也不是转置再求逆。下面的例子说明这一点。

示例 3.73 加权内积下的伴随 设 $V=W=\mathbb{R}^2$ 都取加权内积 $\langle\boldsymbol{x},\boldsymbol{y}\rangle_{\boldsymbol{M}}=\boldsymbol{x}^{\mathsf T}\boldsymbol{M}\boldsymbol{y}$，$\boldsymbol{M}=\operatorname{diag}(4,1)$，并考虑把第二个坐标移到第一个位置的映射 $T\boldsymbol{x}=\boldsymbol{A}\boldsymbol{x}$，其中

$$\boldsymbol{A}=\begin{bmatrix}0&1\\0&0\end{bmatrix}.$$

标准基在这个内积下不是标准正交基，所以伴随要用式 (3.20)计算：

$$\boldsymbol{B} = \boldsymbol{M}^{-1}\boldsymbol{A}^{\top}\boldsymbol{M} = \begin{bmatrix} 1/4 & 0 \\ 0 & 1 \end{bmatrix}\begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix}\begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 4 & 0 \end{bmatrix}.$$

再回到配对等式核对：$\boldsymbol{A}\boldsymbol{x} = (x_2, 0)^{\top}$，$\langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{y}\rangle_{\boldsymbol{M}} = 4x_2y_1$；$\boldsymbol{B}\boldsymbol{y} = (0, 4y_1)^{\top}$，$\langle \boldsymbol{x}, \boldsymbol{B}\boldsymbol{y}\rangle_{\boldsymbol{M}} = x_2 \cdot 4y_1$，两者相等。因数 4 来自输出落在权重为 4 的第一个坐标上，伴随要把这个权重带回输入端。所以伴随矩阵是 $\boldsymbol{B}$，而不是 $\boldsymbol{A}^{\top}$：

$$\boldsymbol{B} = \begin{bmatrix} 0 & 0 \\ 4 & 0 \end{bmatrix} \neq \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix} = \boldsymbol{A}^{\top}.$$

对偶映射的矩阵总是 $\boldsymbol{A}^{\top}$；伴随与它的差别，来自读取与向量之间的对应 $\boldsymbol{a} \mapsto \boldsymbol{M}^{-1}\boldsymbol{a}$ 随内积改变。四个基本子空间正交关系的证明只用到配对恒等式，所以在一般内积空间中同样有 $\ker T^{\star} = (\operatorname{im} T)^{\perp}$、$\ker T = (\operatorname{im} T^{\star})^{\perp}$。

伴随的运算规则　由配对定义可以逐条推出伴随的运算规则：

$$\begin{aligned} (T+S)^{\star} &= T^{\star} + S^{\star}, \\ (cT)^{\star} &= c\,T^{\star}, \\ (TS)^{\star} &= S^{\star}T^{\star}, \\ T^{\star\star} &= T. \end{aligned}$$

例如 $\langle TS\boldsymbol{x}, \boldsymbol{y}\rangle = \langle S\boldsymbol{x}, T^{\star}\boldsymbol{y}\rangle = \langle \boldsymbol{x}, S^{\star}T^{\star}\boldsymbol{y}\rangle$，复合的伴随与乘积的转置一样反转次序；恒等映射的伴随是自身。图 3.7画出伴随怎样把配对从输出端搬回输入端。

伴随不是逆：逆把输出复原成输入，伴随只把作用从内积的一侧移到另一侧。

示例 3.74　反例：伴随不是逆　最简单的反例是非零内积空间 V 上的放大两倍 $T = 2\,\mathrm{id}$。数乘可以从内积的一侧移到另一侧，$\langle 2\boldsymbol{x}, \boldsymbol{y}\rangle = \langle \boldsymbol{x}, 2\boldsymbol{y}\rangle$ 对一切 $\boldsymbol{x}, \boldsymbol{y}$ 成立，所以 $T^{\star} = 2\,\mathrm{id}$：伴随仍是放大两倍。复原输入的逆却是缩小一半，$T^{-1} = \frac{1}{2}\,\mathrm{id}$。因此 $T^{\star} \neq T^{-1}$。两者相等恰好是正交算子的条件，下面马上会遇到。

自伴、正交与正规算子　对算子 $T : V \to V$，伴随仍是 V 上的算子，可以与 T 比较。下面四类算子都由 T 与 $T^{\star}$ 之间的一个等式规定。

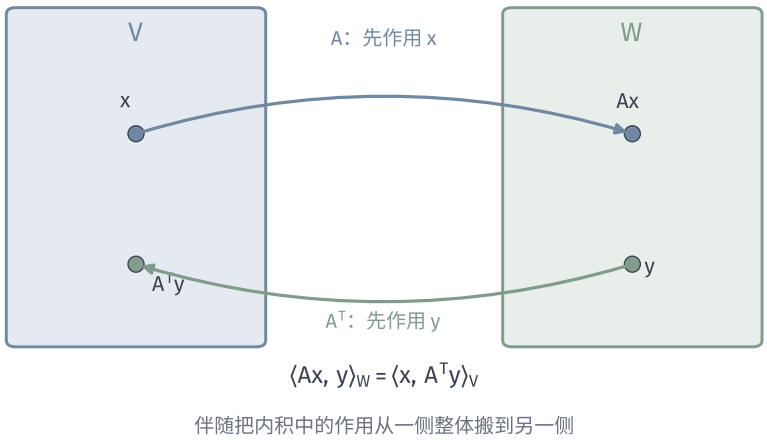


图 3.7 内积伴随把输出端的配对搬回输入端。左：$T: V \to W$ 把 $\boldsymbol{x}$ 映成 $T\boldsymbol{x}$，与 $\boldsymbol{y} \in W$ 配对；右：伴随 $T^\star: W \to V$ 把 $\boldsymbol{y}$ 映回 $T^\star\boldsymbol{y} \in V$，使 $\langle T\boldsymbol{x}, \boldsymbol{y}\rangle_W = \langle \boldsymbol{x}, T^\star\boldsymbol{y}\rangle_V$。标准欧氏内积下 $T^\star$ 就是转置；它反转的是配对的方向，不是逆作用。箭头与空间为解析示意。

若 $T^\star = T$，称 T 为**自伴**（self-adjoint）算子，它在标准正交基下对应对称矩阵。若 $T^\star = -T$，称 T 为**反自伴**（skew-adjoint）算子，它在标准正交基下对应满足 $\boldsymbol{A}^\top = -\boldsymbol{A}$ 的反对称矩阵。反自伴算子把每个向量送到与它正交的方向：由 $\langle T\boldsymbol{x}, \boldsymbol{x}\rangle = \langle \boldsymbol{x}, T^\star\boldsymbol{x}\rangle = -\langle \boldsymbol{x}, T\boldsymbol{x}\rangle$ 得 $\langle T\boldsymbol{x}, \boldsymbol{x}\rangle = 0$。例如平面上的 $\left[\begin{smallmatrix} 0 & -1 \\ 1 & 0 \end{smallmatrix}\right]$ 把 $(x_1, x_2)^\top$ 送到 $(-x_2, x_1)^\top$，即逆时针旋转直角。

若 $Q^\star Q = \mathrm{id}$，则 Q 保持内积：$\langle Q\boldsymbol{x}, Q\boldsymbol{y}\rangle = \langle \boldsymbol{x}, Q^\star Q\boldsymbol{y}\rangle = \langle \boldsymbol{x}, \boldsymbol{y}\rangle$，称为正交算子。它在标准正交基下对应第 3.5.2节的正交矩阵；由方阵的单侧逆即双侧逆，$Q^{-1} = Q^\star$。

满足 $TT^\star = T^\star T$ 的算子称为**正规**(normal)算子,即 T 与自己的伴随可交换。自伴、反自伴与正交算子都是正规算子：前两种情形 $T^\star = \pm T$ 显然与 T 交换,正交算子满足 $QQ^\star = Q^\star Q = \mathrm{id}$。一般算子未必正规,例如示例 3.73中的 $\boldsymbol{A} = \left[\begin{smallmatrix} 0 & 1 \\ 0 & 0 \end{smallmatrix}\right]$ 在欧氏内积下满足 $\boldsymbol{A}\boldsymbol{A}^\top = \mathrm{diag}(1,0) \neq \mathrm{diag}(0,1) = \boldsymbol{A}^\top\boldsymbol{A}$。这些算子的谱性质在第 4章讨论，这里只给出定义。

复空间中的泛函表示与伴随 复空间沿用前面“第一变量共轭线性、第二变量线性”的约定。这时线性泛函应写成 $\varphi(\boldsymbol{x}) = \langle \boldsymbol{v}, \boldsymbol{x}\rangle$，让 $\boldsymbol{x}$ 处于线性的变量位置。若 $\boldsymbol{q}_1, \dots, \boldsymbol{q}_d$ 是标准正交基，则 $\boldsymbol{v} = \sum_j \overline{\varphi(\boldsymbol{q}_j)}\boldsymbol{q}_j$；代入各基向量即可核对读数。表示向量随泛函作共轭线性变化，这与实空间中的线性对应不同。

例如在 $\mathbb{C}$ 的标准内积 $\langle v, z\rangle = \overline{v}z$ 下，泛函 $\varphi(z) = (1+\mathrm{i})z$ 对应 $v = 1-\mathrm{i}$，因为 $\overline{v}z = (1+\mathrm{i})z$。若交换两个变量的位置，得到的表达式关于 z 共轭线性，不再是线性泛函。所以共轭来自内积约定，不能从实数公式中直接删去。

两个复内积空间之间的伴随仍由 $\langle T\boldsymbol{x}, \boldsymbol{y}\rangle_W = \langle \boldsymbol{x}, T^\star \boldsymbol{y}\rangle_V$ 定义。在标准正交基下，若 T 的矩阵为 $\boldsymbol{A}$，伴随的矩阵就是 $\boldsymbol{A}^*$；若两端基的 Gram 矩阵为 $\boldsymbol{M}_V, \boldsymbol{M}_W$，则为 $\boldsymbol{M}_V^{-1}\boldsymbol{A}^*\boldsymbol{M}_W$。这与代数对偶映射的矩阵 $\boldsymbol{A}^{\mathsf{T}}$ 不同：后者只复合线性泛函，不涉及内积和共轭。复空间中，自伴矩阵满足 $\boldsymbol{A} = \boldsymbol{A}^*$；保持内积的方阵满足 $\boldsymbol{A}^*\boldsymbol{A} = \boldsymbol{I}$，称为酉矩阵。

3.7 本章小结

本章回答了章首的三个问题：两个向量相差多少，一列近似是否趋于极限，两个方向是否垂直。前两个问题由范数回答，第三个问题需要内积。

范数给向量规定大小，从而可以度量误差。常用坐标范数之间满足 $\|\boldsymbol{x}\|_q \le \|\boldsymbol{x}\|_p \le d^{1/p-1/q}\|\boldsymbol{x}\|_q$（$p \le q$），比较常数依赖维数，所以同一个误差在不同范数下的读数不同。

有了范数就能谈收敛与连续。向量列与矩阵列的收敛等价于逐坐标、逐元素收敛；映射的联合极限要求所有趋近方式给出同一结果，只检查若干路径只能否定、不能证明极限存在。闭有界集上的连续函数取到最值并且一致连续，闭性、有界性与连续性三个条件缺一不可。

有限维结构带来更强的结论。任意两个范数等价，所以收敛、连续与柯西性质都不依赖所选范数，变的只是误差的数值和比较常数。有限维赋范空间完备，是 Banach 空间，子空间都是闭集；绝对收敛的向量与矩阵级数收敛，并有尾和估计。诱导矩阵范数给出线性映射的最大放大倍数，有限维线性映射因而都 Lipschitz 连续；对偶范数把输入误差的限制转化为线性读取的最大变化；商范数衡量忽略一个子空间中的差别以后剩余的大小。一般范数下向子空间的最近点存在，但可能不唯一。

内积进一步给出长度、夹角和正交。内积诱导的长度是范数，但并非每个范数都来自内积，平行四边形恒等式可以检验这一点；有限维内积空间是 Hilbert 空间。Gram 矩阵记录一组向量的两两内积，它总是半正定的，并且恰在这组向量线性无关时正定；反过来，每个半正定矩阵都是某组向量的 Gram 矩阵，这又推出逐元素乘积保持半正定。

正交分解把向量拆成子空间中的部分与垂直的部分，正交投影是内积诱导距离下唯一的最近点；矩阵是正交投影，当且仅当它幂等且对称。标准正交基使坐标可以由内积直接读出，并保持长度；Gram–Schmidt 正交化保证这样的基总存在，QR 分解把这一过程写成矩阵形式。线性泛函的

内积表示与伴随，把上一章的代数对偶与本章的几何结构联系起来：在标准正交基下伴随就是转置，在一般基下还要计入两端的 Gram 矩阵。

这些结论都依赖有限维：范数等价、完备性与最近点存在的证明，都用到了有限个坐标或闭有界集上的最值。它们为后续各章提供共同依据。第 4章在正交换基下寻找线性作用的简单表示，正交矩阵与自伴算子在那里尤为重要；矩阵幂和级数使用收敛与次乘性，迭代使用完备性和误差估计，多元微分把局部变化表示为线性映射并用算子范数控制余项。

第二部分

谱分析

Spectral Analysis

阅读指引

第一部分把矩阵解释为线性映射在坐标下的记录，并说明同一个映射在不同基下有不同的矩阵。本部分研究怎样选基，才能把一个给定的线性作用看清楚，再用这些表示回答两个实际问题：数据带误差时结果有多可靠，同一个作用反复施加时最终会怎样。

前三章建立表示。特征值与谱分解一章让输入、输出共用一组基，寻找只被伸缩的方向；能用正交基对角化的恰好是对称矩阵，一般方阵只能化为实 Schur 形。奇异值分解一章让两端各取一组标准正交基，使任何矩阵都化为非负的对角伸缩，并由奇异值读出范数和秩。极分解一章把同一作用重新组合为对称伸缩与保长转向，并把开方、求逆等沿谱进行的运算归纳为矩阵函数。

后两章使用这些表示。条件数与谱扰动一章先固定矩阵，研究输入误差的放大，再让矩阵本身带误差，估计特征值、奇异值、秩与特征子空间的变化；所有结论都是有限扰动下的界。线性递推的收敛与稳定性一章研究固定更新的反复作用，由谱半径判断初值影响是否消失，由 Neumann 级数求出平衡，并分析暂时放大与逐步误差的累积。

阅读时要注意区分几组相近的概念：同一组基下的相似变换与两端分别换基；特征值与奇异值；谱半径描述的长期倍率与范数描述的一步放大；输入带误差与矩阵带误差；有限扰动界与沿指定方向的一阶响应。Rayleigh 商以及低秩、正交逼近的最优性在第三部分的矩阵逼近一章讨论；一阶响应与局部条件数在第四部分借助微分讨论。

第 4 章

特征值与谱分解

第 2章说明, 矩阵是线性映射在一组基下的坐标表示。对把空间映到自身的线性算子，输入和输出同时换成一组新基时，矩阵按相似关系 $\boldsymbol{B} = \boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P}$ 改变（第 2.3.4.2节），所以同一个作用有许多种矩阵写法。那里的例子中，算子 $T(x_1, x_2) = (2x_1 + x_2, 3x_2)$ 在标准基下的矩阵有非零的非对角元，换到合适的基以后却成了对角矩阵：新基的两个方向在作用下只被伸缩，不被转向。

本章研究一般的表示问题：给定方阵，能否找到这样的方向？能找到多少？如果还要求新基保持长度和夹角，矩阵最多能化到多简单？这几个问题依次加强对基的要求，答案也依次收窄。

第 4.1节寻找只被伸缩的方向，即特征向量，用特征多项式求出特征值，并说明它们不随基改变。第 4.2节判断特征向量何时多到足以组成一组基；这时矩阵相似于对角矩阵，矩阵幂化为特征值的乘方，但所用的特征基一般不正交。第 4.3节要求换基矩阵正交，证明能这样对角化的恰好是实对称矩阵，并把分解写成与基的选取无关的谱投影之和。第 4.4节处理一般方阵：允许复特征值以后，正交换基只能得到分块上三角的实 Schur 形，能化为分块对角形的恰好是正规矩阵。

本章用到第 1章的矩阵运算与行列式、第 2章的线性映射、换基与相似，以及第 3章的范数、内积、正交投影与正定矩阵。这里得到的谱定理是后面几章的共同工具：第 5章用它构造奇异值分解，第 6章用它开方，第 7章和第 8章用特征值与谱半径分析扰动和反复作用。

4.1 特征值与特征向量

第 2.3.4.2节的例子中，算子 $T(x_1, x_2) = (2x_1 + x_2, 3x_2)$ 换到新基 $\boldsymbol{b}_1' = \boldsymbol{e}_1$、$\boldsymbol{b}_2' = \boldsymbol{e}_1 + \boldsymbol{e}_2$ 以后，矩阵成为对角矩阵 $\mathrm{diag}(2, 3)$，因为这两个基方向在作用下只被伸缩、不被转向。不过，那组基是事先给出、再加以验证的。

本节给出寻找这类方向的一般方法。特征向量的定义只说明要找什么；要系统地找出它们，需要把条件改写成特征多项式的根。求出的特征值还

要与基无关，才是算子本身的性质；最后，不同特征值的特征向量线性无关，这为下一节用它们组成基作准备。

4.1.1　线性作用中的特征方向

第 2.3.1节说明，线性算子 $T : V \to V$ 总把原点留在原处，但一般会同时改变向量的长度和方向。我们要找的是这样的非零向量：作用以后仍落在原来那条过原点的直线上，只被伸长、缩短或反向。用等式表达，就是要求非零向量 $\boldsymbol{v} \in V$ 与实数 λ 满足

$$T\boldsymbol{v} = \lambda \boldsymbol{v}, \qquad \boldsymbol{v} \neq \boldsymbol{0}. \tag{4.1}$$

这时称 λ 为 T 的**特征值**（eigenvalue），$\boldsymbol{v}$ 为属于 λ 的**特征向量**（eigenvector），$\boldsymbol{v}$ 所在的直线称为**特征方向**。

定义要求特征向量非零，因为零向量对任何 λ 都满足 $T\boldsymbol{0} = \lambda\boldsymbol{0}$，不提供方向信息。特征值说明这条直线上发生了什么：$|\lambda| > 1$ 时向量被拉长，$|\lambda| < 1$ 时被缩短，$\lambda < 0$ 时方向还被反过来；$\lambda = 0$ 表示 $T\boldsymbol{v} = \boldsymbol{0}$，即 $\boldsymbol{v}$ 在 T 的核中。

在特征方向上，反复作用也最简单。第 2.3.1节说明，算子可以与自身复合，得到 T^k。对特征向量 $\boldsymbol{v}$，由 $T\boldsymbol{v} = \lambda\boldsymbol{v}$ 与线性性得 $T^2\boldsymbol{v} = T(\lambda\boldsymbol{v}) = \lambda T\boldsymbol{v} = \lambda^2\boldsymbol{v}$，归纳即得 $T^k\boldsymbol{v} = \lambda^k\boldsymbol{v}$。所以在这条直线上，$k$ 次作用化为数 λ 的 k 次乘方。

特征值是算子本身的性质，不依赖基的选取。取一组基 $\mathcal{B}$ 后，式 (4.1)的坐标形式是 $[T]_{\mathcal{B}}[\boldsymbol{v}]_{\mathcal{B}} = \lambda[\boldsymbol{v}]_{\mathcal{B}}$。等式两侧分别是向量 $T\boldsymbol{v}$ 与 $\lambda\boldsymbol{v}$ 的坐标，而 $\boldsymbol{v} \neq \boldsymbol{0}$ 当且仅当它的坐标非零。所以无论取哪组基，矩阵 $[T]_{\mathcal{B}}$ 的特征值都恰好是 T 的特征值；换基只改变特征向量的坐标。

反过来，方阵也可以看作算子。对 n 阶方阵 $\boldsymbol{A}$，它的特征值与特征向量指算子 $\boldsymbol{x} \mapsto \boldsymbol{A}\boldsymbol{x}$ 的特征值与特征向量，即满足 $\boldsymbol{A}\boldsymbol{v} = \lambda\boldsymbol{v}$、$\boldsymbol{v} \neq \boldsymbol{0}$ 的 λ 与 $\boldsymbol{v}$。

回到开头的算子，可以逐个验证哪些方向是特征方向。

示例 4.1　验证特征向量　算子 $T(x_1, x_2) = (2x_1 + x_2, 3x_2)$ 在标准基下的矩阵为

$$\boldsymbol{A} = \begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix}.$$

我们看 $\boldsymbol{e}_1$、$(1,1)^{\mathsf{T}}$ 与 $\boldsymbol{e}_2$ 三个向量中哪些是特征向量。按定义，只需把每个向量乘以 $\boldsymbol{A}$，看结果是否仍是原向量的倍数：

$$\boldsymbol{A}\boldsymbol{e}_1 = \begin{bmatrix} 2 \\ 0 \end{bmatrix} = 2\boldsymbol{e}_1$$

$$\boldsymbol{A}\begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 3 \\ 3 \end{bmatrix} = 3\begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$\boldsymbol{A}\boldsymbol{e}_2 = \begin{bmatrix} 1 \\ 3 \end{bmatrix}.$$

前两个向量只被分别乘以 2 和 3，所以 $\boldsymbol{e}_1$ 与 $(1,1)^{\mathsf{T}}$ 是特征向量，特征值分别为 2 和 3；它们正是第 2.3.4.2节新基的两个方向，这就解释了那组基为什么能把矩阵化成 $\mathrm{diag}(2,3)$。$\boldsymbol{e}_2$ 则被送到 $(1,3)^{\mathsf{T}}$，这不是 $\boldsymbol{e}_2$ 的倍数，所以 $\boldsymbol{e}_2$ 不是特征向量。

图 4.1画出这个例子：两条特征方向上的向量作用后仍在原直线上，只是变长；其他方向上的向量被转开。

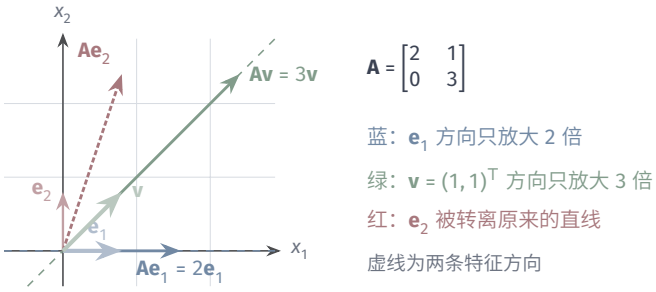


图 4.1　特征向量只被伸缩、不被转向。算子 $T(x_1,x_2)=(2x_1+x_2,3x_2)$ 在标准基下的矩阵为 $\boldsymbol{A}=\left[\begin{smallmatrix}2&1\\0&3\end{smallmatrix}\right]$，它把 $\boldsymbol{e}_1$ 送到 $2\boldsymbol{e}_1$，把 $\boldsymbol{v}=(1,1)^{\mathsf{T}}$ 送到 $3\boldsymbol{v}$，二者都留在各自的虚线上；$\boldsymbol{e}_2$ 被送到 $(1,3)^{\mathsf{T}}$，偏离了原来的直线，所以不是特征向量。

并非每个算子都有实特征向量。下面的反例中，每个非零向量都被转离原来的直线。

示例 4.2　反例：平面旋转没有实特征向量　考虑平面上逆时针旋转 90° 的算子 $R(x_1,x_2)=(-x_2,x_1)$。直观上，每个非零向量都被转过直角，不可能留在原来的直线上；下面用方程确认这一点。设实数 λ 与向量 (x_1,x_2) 满足 $R(x_1,x_2)=\lambda(x_1,x_2)$，按分量写出就是

$$-x_2 = \lambda x_1$$

$$x_1 = \lambda x_2.$$

把第二式代入第一式得 $-x_2 = \lambda^2 x_2$，即 $(1+\lambda^2)x_2 = 0$。由于 $1+\lambda^2 > 0$，只能 $x_2 = 0$，进而 $x_1 = \lambda x_2 = 0$。可见无论取哪个实数 λ，满足等式的都只有零向量，所以 R 既没有实特征值，也没有实特征向量。

4.1.2 特征空间与不变子空间

同一个特征值可以对应不止一条特征方向，所以应把它们放在一起考察。固定特征值 λ，满足 $T\boldsymbol{v} = \lambda\boldsymbol{v}$ 的全部向量连同零向量组成集合 $\ker(T - \lambda\,\mathrm{id}_V)$，称为 λ 的**特征空间**（eigenspace）。它是一个线性映射的核，因而是子空间。

例如 $\boldsymbol{I}_2$ 的每个非零向量都是属于 1 的特征向量，特征空间是整个平面；而示例 4.1中属于 2 的特征空间只是 $\boldsymbol{e}_1$ 所在的直线，因为 $\boldsymbol{A} - 2\boldsymbol{I} = \left[\begin{smallmatrix} 0 & 1 \\ 0 & 1 \end{smallmatrix}\right]$ 的核由第二坐标为零的向量组成。

特征空间是一类更一般的子空间的特例。若子空间 S 满足 $T(S) \subseteq S$，就称 S 为 T 的**不变子空间**（invariant subspace）。这时作用不会把 S 中的向量带出 S，可以把 T 限制在 S 上单独研究。特征空间中的向量只被乘以 λ，仍留在其中，所以特征空间是不变子空间。

一维不变子空间恰好就是特征方向。若 $\boldsymbol{v} \neq \boldsymbol{0}$ 且 $\mathrm{span}\{\boldsymbol{v}\}$ 不变，则 $T\boldsymbol{v}$ 落在这条直线上，是 $\boldsymbol{v}$ 的倍数；反之，若 $T\boldsymbol{v} = \lambda\boldsymbol{v}$，则 $T(c\boldsymbol{v}) = \lambda c\boldsymbol{v}$ 仍在这条直线上。高于一维的不变子空间却未必含有特征方向：整个平面对 90° 旋转不变，而示例 4.2说明其中没有一条特征方向。这样的二维不变子空间对应一对共轭的复特征值（第 4.4节）。

4.1.3 特征多项式

示例 4.1中的特征向量是先猜出、再验证的。要系统地求出全部特征值，可以把特征值的条件改写成矩阵不可逆。对 n 阶方阵 $\boldsymbol{A}$，λ 是特征值，当且仅当齐次方程 $(\boldsymbol{A} - \lambda\boldsymbol{I})\boldsymbol{v} = \boldsymbol{0}$ 有非零解，即 $\ker(\boldsymbol{A} - \lambda\boldsymbol{I}) \neq \{\boldsymbol{0}\}$。由第 2.3.3节的等价条件，这又等价于 $\mathrm{rank}(\boldsymbol{A} - \lambda\boldsymbol{I}) < n$，也等价于 $\boldsymbol{A} - \lambda\boldsymbol{I}$ 不可逆。

不可逆又等价于行列式为零，这一步用到第 1.3.1节的两条性质。若方阵 $\boldsymbol{M}$ 可逆，乘法性给出 $\det\boldsymbol{M}\det(\boldsymbol{M}^{-1}) = \det\boldsymbol{I} = 1$，故 $\det\boldsymbol{M} \neq 0$；反之若 $\det\boldsymbol{M} \neq 0$，古典伴随恒等式说明 $\mathrm{adj}(\boldsymbol{M})/\det\boldsymbol{M}$ 就是 $\boldsymbol{M}$ 的逆。所以 λ 是 $\boldsymbol{A}$ 的特征值，当且仅当 $\det(\boldsymbol{A} - \lambda\boldsymbol{I}) = 0$。

这也解释了第 2.3.4.2节的一个相似不变量。那里把每个 $\mathrm{rank}(\boldsymbol{A} - c\boldsymbol{I})$ 都列为相似不变量；现在可以看出，使这个秩小于 n 的数 c 恰好就是特征值。

把这个条件写成首项系数为 1 的多项式更方便。由于 $\det(\lambda\boldsymbol{I} - \boldsymbol{A}) = (-1)^n\det(\boldsymbol{A} - \lambda\boldsymbol{I})$，二者同时为零。定义

$$p_A(z) = \det(z\boldsymbol{I} - \boldsymbol{A}), \tag{4.2}$$

称为**特征多项式**（characteristic polynomial），就得到：$\boldsymbol{A}$ 的实特征值恰为 $p_{\boldsymbol{A}}$ 的实根。

再看 $p_{\boldsymbol{A}}$ 的次数。在行列式的排列展开中，对角线一项是 $\prod_i (z - a_{i,i})$；其余每一项至少有两个因子取自非对角位置，含 z 的因子至多 $n-2$ 个。所以只有对角线一项含 z^n，$p_{\boldsymbol{A}}$ 是首项系数为 1 的 n 次实多项式，至多有 n 个不同的根。求出一个特征值 λ 以后，再解齐次方程 $(\boldsymbol{A} - \lambda \boldsymbol{I})\boldsymbol{v} = \boldsymbol{0}$，就得到它的特征空间。

用特征多项式可以重新求出前面两个例子的特征值，不必再猜测特征向量。

示例 4.3　用特征多项式求特征值　回到示例 4.1的矩阵 $\boldsymbol{A}$，以及示例 4.2中旋转在标准基下的矩阵 $\boldsymbol{R}$：

$$\boldsymbol{A} = \begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix}, \qquad \boldsymbol{R} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}.$$

这一次不猜特征向量，而是直接计算 $\det(z\boldsymbol{I} - \boldsymbol{A})$ 与 $\det(z\boldsymbol{I} - \boldsymbol{R})$：

$$p_{\boldsymbol{A}}(z) = \det \begin{bmatrix} z-2 & -1 \\ 0 & z-3 \end{bmatrix} = (z-2)(z-3),$$

$$p_{\boldsymbol{R}}(z) = \det \begin{bmatrix} z & 1 \\ -1 & z \end{bmatrix} = z^2 + 1.$$

$p_{\boldsymbol{A}}$ 的两个根 2 与 3 正是示例 4.1中两条特征方向上的伸缩倍数，而且这里不需要事先知道那两条方向。z^2+1 对任何实数 z 都为正，没有实根，所以 $\boldsymbol{R}$ 没有实特征值，与示例 4.2直接解方程的结论一致。

$\boldsymbol{A}$ 的情形可以推广到任意三角矩阵：三角矩阵 $\boldsymbol{A}$ 的 $z\boldsymbol{I} - \boldsymbol{A}$ 仍是三角矩阵，行列式是对角元之积 $\prod_i (z - a_{i,i})$，所以三角矩阵的特征值就是它的对角元。

特征多项式在每个特征值处取零。把矩阵本身代入特征多项式，结果是零矩阵。这里的代入是指把多项式中的 z^j 换成 $\boldsymbol{A}^j$，常数项 c_0 换成 $c_0\boldsymbol{I}$。先在一个例子中验证。

示例 4.4　把矩阵代入它的特征多项式　仍取

$$\boldsymbol{A} = \begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix}.$$

由示例 4.3，$p_{\boldsymbol{A}}(z)=(z-2)(z-3)=z^2-5z+6$。把 z^2 换成 $\boldsymbol{A}^2$、z 换成 $\boldsymbol{A}$、常数 6 换成 $6\boldsymbol{I}$，需要先算出 $\boldsymbol{A}^2$，再逐个元素合并：

$$\boldsymbol{A}^2=\begin{bmatrix}4 & 5\\ 0 & 9\end{bmatrix}$$

$$\boldsymbol{A}^2-5\boldsymbol{A}+6\boldsymbol{I}=\begin{bmatrix}4-10+6 & 5-5+0\\ 0 & 9-15+6\end{bmatrix}=\boldsymbol{0}.$$

四个元素全部抵消，$p_{\boldsymbol{A}}(\boldsymbol{A})$ 是零矩阵。两个对角元分别是 $p_{\boldsymbol{A}}(2)$ 与 $p_{\boldsymbol{A}}(3)$，为零是因为 $2,3$ 是特征值；右上角的抵消则来自 $\boldsymbol{A}^2$ 与 $5\boldsymbol{A}$ 的非对角元恰好相等，单看特征值处取零并不能预见。

这一结论对每个方阵都成立。

定理 4.5　Cayley–Hamilton 定理　设 n 阶方阵 $\boldsymbol{A}$ 的特征多项式为 $p_{\boldsymbol{A}}(z)=z^n+c_{n-1}z^{n-1}+\cdots+c_0$，则

$$p_{\boldsymbol{A}}(\boldsymbol{A})=\boldsymbol{A}^n+c_{n-1}\boldsymbol{A}^{n-1}+\cdots+c_1\boldsymbol{A}+c_0\boldsymbol{I}=\boldsymbol{0}.$$

证明　证明的工具是第 1.3.1.4节的古典伴随恒等式（定理 1.31）$\boldsymbol{M}\,\mathrm{adj}(\boldsymbol{M})=\det(\boldsymbol{M})\boldsymbol{I}$。令 $\boldsymbol{M}=z\boldsymbol{I}-\boldsymbol{A}$，得

$$(z\boldsymbol{I}-\boldsymbol{A})\,\mathrm{adj}(z\boldsymbol{I}-\boldsymbol{A})=p_{\boldsymbol{A}}(z)\boldsymbol{I}.$$

$\mathrm{adj}(z\boldsymbol{I}-\boldsymbol{A})$ 的每个元素都是 $z\boldsymbol{I}-\boldsymbol{A}$ 的一个带符号的 $n-1$ 阶余子式，它是 z 的多项式，次数不超过 $n-1$。按 z 的幂次整理，可以写成 $\mathrm{adj}(z\boldsymbol{I}-\boldsymbol{A})=\sum_{j=0}^{n-1}z^j\boldsymbol{B}_j$，其中 $\boldsymbol{B}_j$ 是不含 z 的常数矩阵。

代入上式，左边为 $\sum_j z^{j+1}\boldsymbol{B}_j-\sum_j z^j\boldsymbol{A}\boldsymbol{B}_j$。两边每个元素都是 z 的多项式，且对所有实数 z 相等，所以同次项的系数相等。记 $c_n=1$，比较 z 的各次幂系数：

$$\begin{aligned}
&z^n:&&\boldsymbol{B}_{n-1}=\boldsymbol{I};\\
&z^j\ (1\le j\le n-1):&&\boldsymbol{B}_{j-1}-\boldsymbol{A}\boldsymbol{B}_j=c_j\boldsymbol{I};\\
&z^0:&&-\boldsymbol{A}\boldsymbol{B}_0=c_0\boldsymbol{I}.
\end{aligned}$$

把 z^j 项的等式左乘 $\boldsymbol{A}^j$（$j=0,\dots,n$）后相加。右边恰为 $\sum_j c_j\boldsymbol{A}^j = p_{\boldsymbol{A}}(\boldsymbol{A})$；左边为

$$\boldsymbol{A}^n\boldsymbol{B}_{n-1} + \sum_{j=1}^{n-1}\left(\boldsymbol{A}^j\boldsymbol{B}_{j-1} - \boldsymbol{A}^{j+1}\boldsymbol{B}_j\right) - \boldsymbol{A}\boldsymbol{B}_0,$$

其中相邻项逐对相消，总和为零。 ■

证明只用到行列式与古典伴随，既不需要先求出特征值，也不要求 $p_{\boldsymbol{A}}$ 有实根。

由定理可以推出，矩阵的高次幂都能由低次幂表示。

定理 4.6　高次幂的降次　设 $\boldsymbol{A}$ 为 n 阶方阵，则对每个整数 $k \geq 0$，

$$\boldsymbol{A}^k \in \operatorname{span}\{\boldsymbol{I}, \boldsymbol{A}, \dots, \boldsymbol{A}^{n-1}\}.$$

因而对任意向量 $\boldsymbol{g}$ 与 $k \geq 0$，

$$\boldsymbol{A}^k\boldsymbol{g} \in \operatorname{span}\{\boldsymbol{g}, \boldsymbol{A}\boldsymbol{g}, \dots, \boldsymbol{A}^{n-1}\boldsymbol{g}\},$$

前 k 项 $\boldsymbol{g},\dots,\boldsymbol{A}^{k-1}\boldsymbol{g}$ 张成的子空间在 $k \geq n$ 时不再增大。

证明　记 $\mathcal{P} = \operatorname{span}\{\boldsymbol{I}, \boldsymbol{A}, \dots, \boldsymbol{A}^{n-1}\}$。$k < n$ 时结论显然。对 $k \geq n$ 归纳。$k = n$ 时，由定理 4.5，

$$\boldsymbol{A}^n = -\sum_{j=0}^{n-1} c_j\boldsymbol{A}^j \in \mathcal{P}.$$

设 $\boldsymbol{A}^k = \sum_{j=0}^{n-1} d_j\boldsymbol{A}^j \in \mathcal{P}$。两边左乘 $\boldsymbol{A}$，得

$$\boldsymbol{A}^{k+1} = \sum_{j=0}^{n-2} d_j\boldsymbol{A}^{j+1} + d_{n-1}\boldsymbol{A}^n.$$

右端第一个和属于 $\mathcal{P}$，$\boldsymbol{A}^n$ 也属于 $\mathcal{P}$，所以 $\boldsymbol{A}^{k+1} \in \mathcal{P}$。

对向量 $\boldsymbol{g}$，把 $\boldsymbol{A}^k = \sum_j d_j\boldsymbol{A}^j$ 作用于 $\boldsymbol{g}$，即得 $\boldsymbol{A}^k\boldsymbol{g} = \sum_{j=0}^{n-1} d_j\boldsymbol{A}^j\boldsymbol{g}$。于是 $k \geq n$ 时新加入的向量 $\boldsymbol{A}^{k-1}\boldsymbol{g}$ 已在前 n 个向量张成的子空间中，子空间不再增大。 ■

所以序列 $\boldsymbol{g}, \boldsymbol{A}\boldsymbol{g}, \boldsymbol{A}^2\boldsymbol{g}, \dots$ 张成的子空间至多是 n 维的，并且由前 n 项决定。第 16章判断 Sylvester 方程何时有唯一解，第 12章研究 Krylov 子空间方法时，都要用到这一点。

回到特征值本身。同一个特征值可以是特征多项式的重根，这时要区分两种“个数”。根 λ 在 $p_{\boldsymbol{A}}$ 中的重数称为**代数重数**（algebraic multiplicity），特征空间的维数 $\dim\ker(\boldsymbol{A}-\lambda\boldsymbol{I})$ 称为**几何重数**（geometric multiplicity）。下面的例子说明二者可以不同。

示例 4.7　代数重数大于几何重数　取

$$\boldsymbol{J}=\begin{bmatrix}0.8 & 1\\ 0 & 0.8\end{bmatrix}.$$

它是上三角矩阵，特征多项式为 $p_{\boldsymbol{J}}(z)=(z-0.8)^2$，所以唯一的特征值 0.8 是二重根，代数重数为 2。要知道几何重数，还得解出特征空间：

$$\boldsymbol{J}-0.8\boldsymbol{I}=\begin{bmatrix}0 & 1\\ 0 & 0\end{bmatrix}$$

$$(\boldsymbol{J}-0.8\boldsymbol{I})\begin{bmatrix}x_1\\ x_2\end{bmatrix}=\begin{bmatrix}x_2\\ 0\end{bmatrix},$$

它为零当且仅当 $x_2=0$，所以特征空间只是 $(1,0)^{\mathsf{T}}$ 所在的直线，几何重数为 1。特征多项式把 0.8 数了两次，特征方向却只有一条；右上角的 1 正是使第二条特征方向消失的原因。

两种重数的一般关系，以及它们怎样决定能否找到由特征向量组成的基，在第 4.2节讨论。对一般的算子 T，可以取任一组基把它写成矩阵，再求特征多项式与两种重数。下一小节说明，结果不依赖基的选取。

4.1.4　相似变换与谱的不变性

第 2.3.4.2节列出了相似保持的量：秩、零空间的维数、每个 $\operatorname{rank}(\boldsymbol{A}-c\boldsymbol{I})$，以及行列式与迹。本小节说明，特征值、特征多项式与两种重数也是相似不变量，因此它们属于算子本身；再说明迹与行列式怎样由特征值读出，最后指出这些不变量只能否定相似。

特征值、特征空间与特征多项式　下面的定理把这些不变性一并写出。

定理 4.8　谱的相似不变性　设 $\boldsymbol{B}=\boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P}$，$\boldsymbol{P}$ 可逆，则：

1. $\boldsymbol{A}$ 与 $\boldsymbol{B}$ 的特征值相同；若 $\boldsymbol{A}\boldsymbol{v}=\lambda\boldsymbol{v}$，则 $\boldsymbol{B}(\boldsymbol{P}^{-1}\boldsymbol{v})=\lambda\boldsymbol{P}^{-1}\boldsymbol{v}$，且 $\ker(\boldsymbol{B}-\lambda\boldsymbol{I})=\boldsymbol{P}^{-1}\ker(\boldsymbol{A}-\lambda\boldsymbol{I})$，所以每个特征值的几何重数相同；
2. $p_{\boldsymbol{B}}=p_{\boldsymbol{A}}$，所以每个特征值的代数重数相同。

证明 第一条。若 $\boldsymbol{A}\boldsymbol{v}=\lambda\boldsymbol{v}$ 且 $\boldsymbol{v}\neq\boldsymbol{0}$，则

$$\boldsymbol{B}(\boldsymbol{P}^{-1}\boldsymbol{v})=\boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P}\boldsymbol{P}^{-1}\boldsymbol{v}=\boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{v}=\lambda\boldsymbol{P}^{-1}\boldsymbol{v}.$$

$\boldsymbol{P}$ 可逆保证 $\boldsymbol{P}^{-1}\boldsymbol{v}\neq\boldsymbol{0}$，所以 λ 也是 $\boldsymbol{B}$ 的特征值；交换 $\boldsymbol{A},\boldsymbol{B}$ 的角色即得反向结论。同样的计算说明 $\boldsymbol{P}^{-1}$ 把 $\ker(\boldsymbol{A}-\lambda\boldsymbol{I})$ 映入 $\ker(\boldsymbol{B}-\lambda\boldsymbol{I})$，交换角色可知 $\boldsymbol{P}$ 把后者映入前者，所以 $\ker(\boldsymbol{B}-\lambda\boldsymbol{I})=\boldsymbol{P}^{-1}\ker(\boldsymbol{A}-\lambda\boldsymbol{I})$。可逆矩阵把子空间映成同维数的子空间，所以几何重数相同。这一结论也可以由式 (2.21)取 $c=\lambda$、再用秩零度定理换成核的维数得到。

第二条。由 $z\boldsymbol{I}=\boldsymbol{P}^{-1}(z\boldsymbol{I})\boldsymbol{P}$ 与第 2.3.4.2节的恒等式 $\det(\boldsymbol{P}^{-1}\boldsymbol{M}\boldsymbol{P})=\det\boldsymbol{M}$，

$$p_{\boldsymbol{B}}(z)=\det(z\boldsymbol{I}-\boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P})=\det\bigl(\boldsymbol{P}^{-1}(z\boldsymbol{I}-\boldsymbol{A})\boldsymbol{P}\bigr)=p_{\boldsymbol{A}}(z).$$

■

所以算子的特征值、特征多项式与两种重数都可以用任意一组基下的矩阵计算。

特征多项式的系数 行列式与迹也是相似不变量，这可以由定理 4.8解释：它们就是 $p_{\boldsymbol{A}}$ 的两个系数，至多差一个符号。

定理 4.9 迹、行列式与特征值 设 $\boldsymbol{A}$ 为 n 阶方阵，则

$$p_{\boldsymbol{A}}(z)=z^{n}-(\operatorname{tr}\boldsymbol{A})\,z^{n-1}+\cdots+(-1)^{n}\det\boldsymbol{A}.$$

若 $p_{\boldsymbol{A}}(z)=\prod_{i=1}^{n}(z-\lambda_i)$ 分解为实一次因子之积，其中每个特征值按代数重数重复列出，则

$$\operatorname{tr}\boldsymbol{A}=\sum_{i=1}^{n}\lambda_i,\qquad\det\boldsymbol{A}=\prod_{i=1}^{n}\lambda_i.$$

证明 令 $z=0$，得常数项 $p_{\boldsymbol{A}}(0)=\det(-\boldsymbol{A})=(-1)^{n}\det\boldsymbol{A}$。再看 z^{n-1} 的系数。第 4.1.3节已经指出，排列展开中除对角线一项外，每一项含 z 的因子至多 $n-2$ 个；所以 z^{n-1} 只来自 $\prod_i(z-a_{i,i})$，系数为 $-\sum_i a_{i,i}=-\operatorname{tr}\boldsymbol{A}$。若 $p_{\boldsymbol{A}}=\prod_i(z-\lambda_i)$，展开右端，$z^{n-1}$ 的系数为 $-\sum_i\lambda_i$，常数项为 $(-1)^{n}\prod_i\lambda_i$，与上面比较即得两个等式。 ■

例如示例 4.1的 $\boldsymbol{A}$ 有 $\operatorname{tr}\boldsymbol{A}=5=2+3$，$\det\boldsymbol{A}=6=2\cdot3$。第 4.4节把特征多项式的复根也算作特征值以后，这两个等式对每个方阵都成立。

相似不变量只能否定相似　相似不变量只能用来否定相似：某个相似不变量不同，两个矩阵就不相似；不变量全部相同，两个矩阵却未必相似。第 2.3.4.2节比较过 $\boldsymbol{I}_2$ 与 $\left[\begin{smallmatrix}1&1\\0&1\end{smallmatrix}\right]$，下面用特征值的语言重新说明二者为什么不相似。

示例 4.10　反例：特征多项式相同而不相似　比较 $\boldsymbol{I}_2$ 与

$$\boldsymbol{J}_1 = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}.$$

二者都是上三角矩阵，对角元都是 1，所以 $p_{\boldsymbol{I}_2}(z) = p_{\boldsymbol{J}_1}(z) = (z-1)^2$，特征值 1 的代数重数都是 2。仅凭特征多项式无法把它们区分开，于是转而比较特征空间：

$$\boldsymbol{I}_2 - \boldsymbol{I}_2 = \boldsymbol{0}$$
$$\boldsymbol{J}_1 - \boldsymbol{I}_2 = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix},$$

前者的核是整个平面，后者的核只是 $(1,0)^{\mathsf{T}}$ 所在的直线，几何重数分别为 2 与 1。由定理 4.8，相似矩阵的几何重数必须相同，所以二者不相似，尽管它们的特征多项式完全一样。

所以特征多项式相同只是相似的必要条件。比较各特征值的几何重数是更细的必要条件，但一般仍不足以判定相似；完整的相似分类需要 Jordan 标准形，本书不展开。

4.1.5　特征向量的线性无关性

要用特征方向组成一组基，先要知道不同特征值的特征向量彼此不会重复。本小节先证明它们线性无关，再推出各特征空间之和是直和。

特征向量的线性无关　设想两条特征方向属于不同的特征值。若其中一条落在另一条上，同一个向量就会被乘以两个不同的倍数，这不可能。下面的定理把这一观察推广到任意多个特征值。

定理 4.11　不同特征值的特征向量线性无关　设 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_r$ 分别是 T 属于互不相同的特征值 $\lambda_1, \dots, \lambda_r$ 的特征向量，则 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_r$ 线性无关。特别地，n 维空间上的算子至多有 n 个不同的特征值。

证明 假设它们线性相关。在所有非平凡的线性依赖中取项数最少的一个，重新编号后记为 $\sum_{j=1}^{s} c_j \boldsymbol{v}_j = \boldsymbol{0}$，其中各 $c_j \neq 0$；单个特征向量非零，不能单独构成依赖，所以 $s \geq 2$。两边作用 $T - \lambda_1 \mathrm{id}_V$：第一项变为零，其余各项变为 $c_j(\lambda_j - \lambda_1)\boldsymbol{v}_j$。特征值互不相同，这些系数仍非零，于是得到一个只有 $s-1$ 项的非平凡依赖，与 s 最少矛盾。n 维空间中线性无关的向量至多 n 个，所以不同特征值至多 n 个。 ■

这一上界与特征多项式的次数给出的上界一致。

特征空间的直和 同一个特征值可以有多维的特征空间。从每个特征空间各取一组基，合在一起是否仍线性无关？下面的定理给出肯定回答。

定理 4.12 特征空间之和是直和 设 $\lambda_1, \dots, \lambda_r$ 是 T 的互不相同的特征值，$E_i = \ker(T - \lambda_i \mathrm{id}_V)$。则和 $E_1 + \cdots + E_r$ 是直和；把各 E_i 的基合在一起，仍线性无关，因而 $\dim(E_1 + \cdots + E_r) = \sum_i \dim E_i$。

证明 设 $\boldsymbol{w}_1 + \cdots + \boldsymbol{w}_r = \boldsymbol{0}$，$\boldsymbol{w}_i \in E_i$。其中非零的 $\boldsymbol{w}_i$ 是属于不同特征值的特征向量，由定理 4.11线性无关，不能相加为零，所以每个 $\boldsymbol{w}_i = \boldsymbol{0}$，和是直和。把各 E_i 的基合在一起，它们的任一线性组合都可以按特征值分组写成 $\sum_i \boldsymbol{w}_i$；若组合为零，则每个 $\boldsymbol{w}_i = \boldsymbol{0}$，而每组基本身线性无关，所以全部系数为零。 ■

例如示例 4.1中的 $\boldsymbol{e}_1$ 与 $(1,1)^{\mathsf{T}}$ 属于不同的特征值 2 与 3，不必另行验证，它们自动线性无关，在平面上组成一组基。

回顾本节：被算子只伸缩的方向是特征方向，伸缩倍数是特征值。特征值是特征多项式的实根，求出特征值后解齐次方程即得特征空间。特征值、特征多项式和两种重数都不随基改变，属于算子本身。

属于不同特征值的特征向量线性无关，所以 n 维空间上的算子至多有 n 个不同特征值。此外，Cayley–Hamilton 定理说明 $p_A(\boldsymbol{A}) = \boldsymbol{0}$，由此 $\boldsymbol{A}$ 的高次幂都能用 $\boldsymbol{I}, \boldsymbol{A}, \dots, \boldsymbol{A}^{n-1}$ 表示（定理 4.6）。特征向量什么时候多到足以组成一组基，是下一节的对角化问题。

4.2 对角化

上一节找到了被算子只伸缩的方向，并证明属于不同特征值的特征向量线性无关。本节考察这些方向足以组成一组基的情形。先看这时矩阵和矩阵幂变成什么样，由此明白这种基为什么值得寻找；再给出它存在的条件，最后整理计算步骤。

本节的换基矩阵只要求可逆，各列不必互相垂直；要求正交换基的情形留给下一节。

4.2.1　特征向量基下的矩阵表示

设 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_n$ 是由算子 T 的特征向量组成的基，$T\boldsymbol{v}_j = \lambda_j \boldsymbol{v}_j$。按第 2.3.1节的约定，$T$ 在这组基下的矩阵的第 j 列是 $T\boldsymbol{v}_j = \lambda_j \boldsymbol{v}_j$ 的坐标，即第 j 个位置为 λ_j、其余位置为零。所以这个矩阵在主对角线以外全为零，每个基方向被独立地伸缩。

示例 4.1中的 $(\boldsymbol{e}_1, (1,1)^{\mathsf{T}})$ 就是这样一组基。换到这组基，正是第 2.3.4.2节的相似变换 $\boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P} = \operatorname{diag}(2,3)$；在图 2.10中，基向量围成的平行四边形只沿两条特征方向分别伸长 2 倍和 3 倍。

这一观察可以写成矩阵等式。设 $\boldsymbol{A}$ 是 T 在标准基下的矩阵，把特征向量的标准坐标排成 $\boldsymbol{V} = [\boldsymbol{v}_1, \dots, \boldsymbol{v}_n]$。$\boldsymbol{V}$ 的各列是新基向量的旧坐标，所以它正是第 2.3.4.2节的换基矩阵；各列线性无关，所以 $\boldsymbol{V}$ 可逆（第 2.3.3节）。

再比较 $\boldsymbol{A}\boldsymbol{V}$ 与 $\boldsymbol{V}\boldsymbol{\Lambda}$。按乘积的列读法，$\boldsymbol{A}\boldsymbol{V}$ 的第 j 列是 $\boldsymbol{A}\boldsymbol{v}_j = \lambda_j \boldsymbol{v}_j$；右乘对角矩阵 $\boldsymbol{\Lambda} = \operatorname{diag}(\lambda_1, \dots, \lambda_n)$ 把第 j 列乘以 λ_j，所以 $\boldsymbol{V}\boldsymbol{\Lambda}$ 的第 j 列也是 $\lambda_j \boldsymbol{v}_j$。于是 $\boldsymbol{A}\boldsymbol{V} = \boldsymbol{V}\boldsymbol{\Lambda}$，两边左乘或右乘 $\boldsymbol{V}^{-1}$，即得

$$\boldsymbol{V}^{-1}\boldsymbol{A}\boldsymbol{V} = \boldsymbol{\Lambda}$$
$$\boldsymbol{A} = \boldsymbol{V}\boldsymbol{\Lambda}\boldsymbol{V}^{-1}.$$

对角形式的好处在反复作用时最明显。定常迭代 $\boldsymbol{x}^{(k+1)} = \boldsymbol{A}\boldsymbol{x}^{(k)}$ 走 k 步后得到 $\boldsymbol{x}^{(k)} = \boldsymbol{A}^k \boldsymbol{x}^{(0)}$。第 1.2.9节规定了矩阵幂的写法，但直接连乘会不断混合各个坐标，看不出 $\boldsymbol{A}^k$ 在 k 很大时是什么样子。把 $\boldsymbol{A} = \boldsymbol{V}\boldsymbol{\Lambda}\boldsymbol{V}^{-1}$ 连乘 k 次，相邻的 $\boldsymbol{V}^{-1}\boldsymbol{V}$ 相消（这就是式 (2.20)后面的 $\boldsymbol{B}^k = \boldsymbol{P}^{-1}\boldsymbol{A}^k\boldsymbol{P}$），得到

$$\begin{aligned} \boldsymbol{A}^k &= \boldsymbol{V}\boldsymbol{\Lambda}^k\boldsymbol{V}^{-1} \\ \boldsymbol{\Lambda}^k &= \operatorname{diag}(\lambda_1^k, \dots, \lambda_n^k). \end{aligned} \tag{4.3}$$

于是求幂只需对对角元逐个乘方。

三个因子可以从右向左读：$\boldsymbol{V}^{-1}\boldsymbol{x}^{(0)}$ 给出初值在各特征方向上的坐标，$\boldsymbol{\Lambda}^k$ 把第 j 个坐标乘以 λ_j^k，$\boldsymbol{V}$ 再把结果合回标准坐标。上一节已经看到，沿特征方向有 $\boldsymbol{A}^k\boldsymbol{v} = \lambda^k\boldsymbol{v}$；式 (4.3)把这一点推广到任意初值。

下面用一个上三角矩阵演示这种计算。先把一个初值拆成特征方向上的分量，再对所有初值一并写出矩阵幂。

示例 4.13　用特征向量计算矩阵幂　我们来求

$$\boldsymbol{A}=\begin{bmatrix}0.8 & 4\\ 0 & 0.5\end{bmatrix}$$

的 k 次幂。直接连乘时，右上角的 4 会把两个坐标不断混在一起，很难看出 $\boldsymbol{A}^k$ 的规律；换到特征方向上，每一步就只是乘一个数。

先找出特征方向。$\boldsymbol{A}$ 是上三角矩阵，特征值就是对角元 0.8 与 0.5。0.8 的特征向量可以取 $\boldsymbol{e}_1$；0.5 的特征向量由 $(\boldsymbol{A}-0.5\boldsymbol{I})\boldsymbol{v}=\boldsymbol{0}$ 的第一行 $0.3v_1+4v_2=0$ 解出，取 $v_2=1$。把两者代回验证：

$$\boldsymbol{A}\begin{bmatrix}1\\0\end{bmatrix}=0.8\begin{bmatrix}1\\0\end{bmatrix}$$

$$\boldsymbol{A}\begin{bmatrix}-40/3\\1\end{bmatrix}=\begin{bmatrix}-32/3+4\\0.5\end{bmatrix}=0.5\begin{bmatrix}-40/3\\1\end{bmatrix},$$

所以 $\boldsymbol{v}_1=(1,0)^{\mathsf{T}}$ 与 $\boldsymbol{v}_2=(-40/3,1)^{\mathsf{T}}$ 是特征向量。

接着跟踪一条轨迹。初值 $(0,1)^{\mathsf{T}}$ 不在特征方向上，但可以拆成 $(0,1)^{\mathsf{T}}=\frac{40}{3}\boldsymbol{v}_1+\boldsymbol{v}_2$。每作用一次，两个分量分别乘以 0.8 与 0.5，互不干扰，由线性性得

$$\boldsymbol{A}^k\begin{bmatrix}0\\1\end{bmatrix}=\frac{40}{3}\,0.8^k\boldsymbol{v}_1+0.5^k\boldsymbol{v}_2=\begin{bmatrix}\frac{40}{3}(0.8^k-0.5^k)\\0.5^k\end{bmatrix}.$$

取 $k=1$ 得 $(4,0.5)^{\mathsf{T}}$，与直接计算 $\boldsymbol{A}(0,1)^{\mathsf{T}}$ 一致。

对任意初值都这样拆分、再合回，就是式 (4.3)。以两个特征向量为列，取

$$\boldsymbol{V}=\begin{bmatrix}1 & -\frac{40}{3}\\ 0 & 1\end{bmatrix},\qquad \boldsymbol{V}^{-1}=\begin{bmatrix}1 & \frac{40}{3}\\ 0 & 1\end{bmatrix},$$

则

$$\boldsymbol{A}^k=\boldsymbol{V}\begin{bmatrix}0.8^k & 0\\ 0 & 0.5^k\end{bmatrix}\boldsymbol{V}^{-1}=\begin{bmatrix}0.8^k & \frac{40}{3}(0.8^k-0.5^k)\\ 0 & 0.5^k\end{bmatrix}.$$

$\boldsymbol{A}^k$ 的第二列正是上面那条轨迹。整个迭代由此拆成两个独立的数列，分别按 0.8^k 与 0.5^k 衰减；右上角的 4 只影响特征向量 $\boldsymbol{v}_2$ 的形状，不影响衰减的速度。

这种计算的前提是特征向量足以组成整个空间的一组基。下一小节讨论这个前提何时成立。

4.2.2 可对角化的判别

上一小节说明，有了由特征向量组成的基，$\boldsymbol{A}$ 就相似于一个对角矩阵。我们把相似于对角矩阵取作定义。

定义 4.14 实可对角化 设 $\boldsymbol{A}$ 是 n 阶实方阵。若存在 n 阶实可逆矩阵 $\boldsymbol{V}$ 与实对角矩阵 $\boldsymbol{\Lambda}$ 使 $\boldsymbol{V}^{-1}\boldsymbol{A}\boldsymbol{V}=\boldsymbol{\Lambda}$，即 $\boldsymbol{A}$ 相似于实对角矩阵，就称 $\boldsymbol{A}$**实可对角化**（diagonalizable over the reals）；求出这样的 $\boldsymbol{V}$ 与 $\boldsymbol{\Lambda}$，称为把 $\boldsymbol{A}$ 对角化。

“实”表示 $\boldsymbol{V}$ 与 $\boldsymbol{\Lambda}$ 的元素都是实数。本书在实数范围内讨论，下文所说的可对角化都指实可对角化。下面的判据把可对角化归结为特征向量是否足够多。

定理 4.15 对角化判据 n 阶实方阵 $\boldsymbol{A}$ 实可对角化，当且仅当 $\boldsymbol{A}$ 有 n 个线性无关的实特征向量。这时以这些特征向量为列组成 $\boldsymbol{V}$，以相应特征值按同一顺序组成 $\boldsymbol{\Lambda}=\operatorname{diag}(\lambda_1,\dots,\lambda_n)$，就有 $\boldsymbol{V}^{-1}\boldsymbol{A}\boldsymbol{V}=\boldsymbol{\Lambda}$。

证明 设 $\boldsymbol{V}$ 的各列为 $\boldsymbol{v}_1,\dots,\boldsymbol{v}_n$，$\boldsymbol{\Lambda}=\operatorname{diag}(\lambda_1,\dots,\lambda_n)$。上一小节的列读法对任意这样的 $\boldsymbol{V}$ 与 $\boldsymbol{\Lambda}$ 都成立，它给出

$$\boldsymbol{A}\boldsymbol{V}=\boldsymbol{V}\boldsymbol{\Lambda} \iff \boldsymbol{A}\boldsymbol{v}_j=\lambda_j\boldsymbol{v}_j \qquad j=1,\dots,n.$$

若 $\boldsymbol{A}$ 有 n 个线性无关的特征向量，以它们为列的 $\boldsymbol{V}$ 可逆，左乘 $\boldsymbol{V}^{-1}$ 即得 $\boldsymbol{V}^{-1}\boldsymbol{A}\boldsymbol{V}=\boldsymbol{\Lambda}$。反过来，若 $\boldsymbol{V}^{-1}\boldsymbol{A}\boldsymbol{V}=\boldsymbol{\Lambda}$，左乘 $\boldsymbol{V}$ 得 $\boldsymbol{A}\boldsymbol{V}=\boldsymbol{V}\boldsymbol{\Lambda}$，于是每列都满足 $\boldsymbol{A}\boldsymbol{v}_j=\lambda_j\boldsymbol{v}_j$；$\boldsymbol{V}$ 可逆，所以各列线性无关，从而都非零，它们是 n 个线性无关的特征向量。 ■

由于属于不同特征值的特征向量线性无关（第 4.1.5节），判据给出一个常用的充分条件：n 阶实方阵若有 n 个互不相同的实特征值，就实可对角化。示例 4.13的矩阵即属此类。这个条件不是必要的：单位矩阵 $\boldsymbol{I}_n$ 只有一个特征值 1，本身却已经是对角矩阵。

不能对角化的矩阵 判据要求 n 个线性无关的实特征向量，这一要求可能在两处落空。其一，实特征值不够。示例 4.2与示例 4.3已经说明，平面上的 90° 旋转 $\boldsymbol{R}=\left[\begin{smallmatrix}0&-1\\1&0\end{smallmatrix}\right]$ 没有实特征值，也就没有实特征向量，所以不能实对角化。

其二，实特征值有了，特征向量却不够。示例 4.7中的 $\boldsymbol{J}=\left[\begin{smallmatrix}0.8 & 1\\ 0 & 0.8\end{smallmatrix}\right]$ 只有特征值 0.8，而特征向量只有 $(1,0)^{\mathsf{T}}$ 的倍数，凑不出两个线性无关的特征向量，所以 $\boldsymbol{J}$ 也不能对角化。

对这样的矩阵，式 (4.3)不再可用，幂也不再是纯粹的乘方。下面直接计算 $\boldsymbol{J}^k$ 来看这一点。

示例 4.16　不能对角化矩阵的幂　对

$$\boldsymbol{J}=\begin{bmatrix}0.8 & 1\\ 0 & 0.8\end{bmatrix},$$

找不到特征向量基，只能另想办法计算 $\boldsymbol{J}^k$。把 $\boldsymbol{J}$ 拆成纯伸缩 $0.8\boldsymbol{I}$ 与剩下的部分 $\boldsymbol{N}$：

$$\boldsymbol{N}=\begin{bmatrix}0 & 1\\ 0 & 0\end{bmatrix}$$

$$\boldsymbol{N}^2=\boldsymbol{0}.$$

$0.8\boldsymbol{I}$ 与 $\boldsymbol{N}$ 可交换，所以二项式展开成立；又因为 $j\geq 2$ 时 $\boldsymbol{N}^j=\boldsymbol{0}$，展开后只剩前两项：

$$\boldsymbol{J}^k=(0.8\boldsymbol{I}+\boldsymbol{N})^k=0.8^k\boldsymbol{I}+k\,0.8^{k-1}\boldsymbol{N}=\begin{bmatrix}0.8^k & k\,0.8^{k-1}\\ 0 & 0.8^k\end{bmatrix}.$$

对角元仍是特征值的乘方 0.8^k，新出现的是右上角的 $k\,0.8^{k-1}$。看它怎样变化，可以比较相邻两项：

$$\frac{(k+1)\,0.8^k}{k\,0.8^{k-1}}=0.8\cdot\frac{k+1}{k},$$

它在 $k<4$ 时大于 1，在 $k>4$ 时小于 1。所以右上角先增大、后衰减：多项式因子 k 在开始阶段压过了 0.8^{k-1} 的衰减。这种先升后降的行为不能由单个特征值的乘方描述，正是特征向量不足的代价。

重数判据　两个反例的缺陷可以用重数说明。$\boldsymbol{R}$ 的特征多项式 z^2+1 不能分解为实一次因子；$\boldsymbol{J}$ 的特征多项式 $(z-0.8)^2$ 分解了，但特征值 0.8 的几何重数 1 小于代数重数 2。下面证明，这两种缺陷恰好是全部障碍。于是能否对角化可以直接由特征多项式和特征空间的维数判断，不必逐个尝试特征向量。

先比较两种重数。

定理 4.17 几何重数不超过代数重数 设 λ 是 n 阶方阵 $\boldsymbol{A}$ 的特征值，几何重数为 $g = \dim\ker(\boldsymbol{A}-\lambda\boldsymbol{I})$，代数重数为 m，则 $1 \le g \le m$。更确切地，$(z-\lambda)^g$ 整除 $p_{\boldsymbol{A}}(z)$。

证明 λ 是特征值，特征空间非零，所以 $g \ge 1$。取特征空间的一组基 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_g$，并扩充成全空间的一组基，以它们为列组成可逆矩阵 $\boldsymbol{P}$。前 g 个基向量都被送到自身的 λ 倍，所以 $\boldsymbol{AP}$ 的前 g 列是 $\lambda\boldsymbol{v}_1, \dots, \lambda\boldsymbol{v}_g$，即 $\boldsymbol{P}^{-1}\boldsymbol{AP}$ 的前 g 列是 $\lambda\boldsymbol{e}_1, \dots, \lambda\boldsymbol{e}_g$。于是 $\boldsymbol{A}$ 相似于分块上三角矩阵

$$\begin{bmatrix} \lambda\boldsymbol{I}_g & * \\ \boldsymbol{0} & \boldsymbol{C} \end{bmatrix}.$$

相似不改变特征多项式（第 4.1.4节），所以可以用这个分块矩阵计算 $p_{\boldsymbol{A}}$。用 $z\boldsymbol{I}$ 减去它以后，前 g 列都只在对角位置上有非零元素 $z-\lambda$。沿第一列按余子式展开（第 1.3.1.4节），得到 $z-\lambda$ 乘以一个形状相同、但只剩 $g-1$ 个这种列的行列式；重复 g 次，即得 $p_{\boldsymbol{A}}(z) = (z-\lambda)^g\, p_{\boldsymbol{C}}(z)$。所以 λ 作为 $p_{\boldsymbol{A}}$ 的根，重数至少为 g，即 $m \ge g$。 ■

示例 4.7说明不等号可以严格成立：那里 $g = 1$ 而 $m = 2$。

有了这个不等式，就可以把对角化判据中“n 个线性无关的特征向量”换成只涉及特征多项式和特征空间维数的条件。

定理 4.18 重数判据 n 阶实方阵 $\boldsymbol{A}$ 实可对角化，当且仅当以下两条同时成立：特征多项式 $p_{\boldsymbol{A}}$ 能分解为 n 个实一次因子之积；每个实特征值的几何重数等于它的代数重数。

证明 先证充分性。$p_{\boldsymbol{A}}$ 分解为 n 个实一次因子时，各特征值的代数重数之和为 n；几何重数与代数重数逐个相等，所以几何重数之和也是 n。由第 4.1.5节，不同特征值的特征空间之和是直和，各特征空间的基合在一起仍线性无关，于是恰好得到 n 个线性无关的特征向量；由定理 4.15，$\boldsymbol{A}$ 实可对角化。

再证必要性。若 $\boldsymbol{A} = \boldsymbol{V}\boldsymbol{\Lambda}\boldsymbol{V}^{-1}$，则由相似不变性，$p_{\boldsymbol{A}} = p_{\boldsymbol{\Lambda}} = \prod_i (z-\lambda_i)$ 已分解为实一次因子。对每个特征值 λ，它在 $\boldsymbol{\Lambda}$ 对角线上出现的次数既是代数重数，也是 $\boldsymbol{\Lambda}-\lambda\boldsymbol{I}$ 的零空间维数，即 $\boldsymbol{\Lambda}$ 的几何重数。由第 4.1.4节，相似不改变几何重数，所以 $\boldsymbol{A}$ 的两种重数也相等。 ■

有 n 个互不相同的实特征值时，每个代数重数都是 1，几何重数至少为 1 又不超过 1，定理 4.18的两个条件自动满足。这就回到了前面的充分条件。

4.2.3 对角化的计算与用途

按判据，对角化分四步。第一步，求出特征多项式 $p_{\boldsymbol{A}}$ 的全部实根，即全部实特征值。第二步，对每个特征值 λ 解齐次方程 $(\boldsymbol{A}-\lambda\boldsymbol{I})\boldsymbol{v}=\boldsymbol{0}$，得到特征空间的一组基。第三步，若这些向量合起来共有 n 个，就以它们为列组成 $\boldsymbol{V}$，以对应的特征值按同一顺序组成 $\boldsymbol{\Lambda}$。第四步，核对 $\boldsymbol{AV}=\boldsymbol{V\Lambda}$。

这四步也会告诉我们何时失败。若特征多项式不能分解为实一次因子，或某个特征空间的维数小于相应的代数重数，过程就在第一步或第三步停止，矩阵不能实对角化。这正是上一小节的两种情形。

下面用一个两状态转移的例子走一遍这四步。设一个群体在两个状态之间转移：每期处于状态一的个体有 10% 转入状态二，处于状态二的个体有 20% 转入状态一。记第 k 期两个状态所占的比例为 $\boldsymbol{x}^{(k)}=(x_1^{(k)},x_2^{(k)})^{\mathsf{T}}$，则下一期状态一的比例为 $0.9x_1^{(k)}+0.2x_2^{(k)}$，状态二的比例为 $0.1x_1^{(k)}+0.8x_2^{(k)}$，即

$$\boldsymbol{x}^{(k+1)}=\boldsymbol{A}\boldsymbol{x}^{(k)},\qquad \boldsymbol{A}=\begin{bmatrix}0.9 & 0.2\\ 0.1 & 0.8\end{bmatrix}.$$

示例 4.19　两状态转移矩阵的对角化　我们按四步把上面的转移矩阵 $\boldsymbol{A}$ 对角化。

先由特征多项式求特征值：

$$p_{\boldsymbol{A}}(z)=(z-0.9)(z-0.8)-0.2\cdot 0.1=z^2-1.7z+0.7=(z-1)(z-0.7),$$

得 $\lambda_1=1$、$\lambda_2=0.7$。两个特征值不同，由前面的充分条件，$\boldsymbol{A}$ 一定可对角化，剩下的只是把特征向量求出来。

两个特征值对应的齐次方程的系数矩阵为

$$\boldsymbol{A}-\boldsymbol{I}=\begin{bmatrix}-0.1 & 0.2\\ 0.1 & -0.2\end{bmatrix},\qquad \boldsymbol{A}-0.7\boldsymbol{I}=\begin{bmatrix}0.2 & 0.2\\ 0.1 & 0.1\end{bmatrix}.$$

$\lambda_1=1$ 时两行成比例，方程化为 $-0.1x_1+0.2x_2=0$，取 $\boldsymbol{v}_1=(2,1)^{\mathsf{T}}$。$\lambda_2=0.7$ 时方程化为 $x_1+x_2=0$，取 $\boldsymbol{v}_2=(1,-1)^{\mathsf{T}}$。每个特征空间都是一条直线，合起来恰有两个特征向量，于是可以组成

$$\boldsymbol{V}=\begin{bmatrix}2 & 1\\ 1 & -1\end{bmatrix},\qquad \boldsymbol{\Lambda}=\begin{bmatrix}1 & 0\\ 0 & 0.7\end{bmatrix},\qquad \boldsymbol{V}^{-1}=\frac{1}{3}\begin{bmatrix}1 & 1\\ 1 & -2\end{bmatrix},$$

其中 $\boldsymbol{V}^{-1}$ 由二阶逆矩阵公式得到，$\det \boldsymbol{V} = -3$。

最后逐列核对：

$$\boldsymbol{A}\boldsymbol{v}_1 = \begin{bmatrix} 1.8 + 0.2 \\ 0.2 + 0.8 \end{bmatrix} = \boldsymbol{v}_1$$

$$\boldsymbol{A}\boldsymbol{v}_2 = \begin{bmatrix} 0.9 - 0.2 \\ 0.1 - 0.8 \end{bmatrix} = 0.7\boldsymbol{v}_2,$$

所以 $\boldsymbol{A}\boldsymbol{V} = \boldsymbol{V}\boldsymbol{\Lambda}$，即 $\boldsymbol{A} = \boldsymbol{V}\boldsymbol{\Lambda}\boldsymbol{V}^{-1}$。上一节的系数关系还提供了一个不必相乘的快速检查：$\operatorname{tr}\boldsymbol{A} = 1.7 = 1 + 0.7$，$\det\boldsymbol{A} = 0.7 = 1 \cdot 0.7$。

有了这个分解，就可以按式 (4.3)求出这个群体的长期比例。

示例 4.20　转移矩阵的长期比例　我们想知道，经过很多期以后两个状态各占多少比例。沿用示例 4.19的分解，由式 (4.3)，

$$\boldsymbol{A}^k = \boldsymbol{V}\begin{bmatrix} 1 & 0 \\ 0 & 0.7^k \end{bmatrix}\boldsymbol{V}^{-1} = \frac{1}{3}\begin{bmatrix} 2 + 0.7^k & 2 - 2\cdot 0.7^k \\ 1 - 0.7^k & 1 + 2\cdot 0.7^k \end{bmatrix};$$

取 $k = 1$，右端正是 $\boldsymbol{A}$。若开始时全部个体处于状态一，即 $\boldsymbol{x}^{(0)} = (1, 0)^{\top}$，则 $\boldsymbol{x}^{(k)}$ 是 $\boldsymbol{A}^k$ 的第一列：

$$\boldsymbol{x}^{(k)} = \frac{1}{3}\begin{bmatrix} 2 + 0.7^k \\ 1 - 0.7^k \end{bmatrix} \to \begin{bmatrix} 2/3 \\ 1/3 \end{bmatrix} \qquad (k \to \infty).$$

极限是否依赖这个特殊的出发点？对一般的初始比例 $\boldsymbol{x}^{(0)} = (a, 1 - a)^{\top}$，$\boldsymbol{V}^{-1}\boldsymbol{x}^{(0)}$ 给出它在两条特征方向上的分量：

$$\boldsymbol{V}^{-1}\boldsymbol{x}^{(0)} = \frac{1}{3}\begin{bmatrix} a + (1 - a) \\ a - 2(1 - a) \end{bmatrix} = \begin{bmatrix} 1/3 \\ (3a - 2)/3 \end{bmatrix}.$$

沿 $\boldsymbol{v}_1$ 的分量总是 $1/3$，与 a 无关；沿 $\boldsymbol{v}_2$ 的分量每期乘以 0.7 而趋于零。所以无论从什么比例出发，长期比例都是 $\frac{1}{3}\boldsymbol{v}_1 = (2/3, 1/3)^{\top}$：特征值 1 的方向决定极限，特征值 0.7 只决定趋近的快慢。

回顾本节：在由特征向量组成的基下，算子的矩阵是对角的：以特征向量为列的 $\boldsymbol{V}$ 把 $\boldsymbol{A}$ 化为 $\boldsymbol{\Lambda}$，反复作用化为特征值的乘方，

$$\boldsymbol{A}^k = \boldsymbol{V}\boldsymbol{\Lambda}^k\boldsymbol{V}^{-1}.$$

n 阶矩阵可对角化，当且仅当它有 n 个线性无关的实特征向量；等价地，特征多项式分解为实一次因子，且每个特征值的几何重数等于代数重数。

实特征值不足或特征向量不足时，矩阵不能对角化；后一种情形的幂含有随 k 增长的多项式因子。

对角化只要求基方向被伸缩，没有要求它们互相垂直。示例 4.19中的两条特征方向 $(2,1)^{\mathsf{T}}$ 与 $(1,-1)^{\mathsf{T}}$ 内积为 1，并不垂直。换到这样的基，求新坐标要解方程，新坐标的平方和也不等于原向量长度的平方。下一节研究哪些矩阵具有一组标准正交的特征向量，即能用正交矩阵对角化。

4.3 正交对角化

上一节用特征向量基完成对角化，只要求换基矩阵 $\boldsymbol{V}$ 可逆，不要求它的各列互相垂直。这样的特征基一般是斜基：坐标的平方和不再等于向量长度的平方，坐标轴之间的夹角也不再是直角。本节继续同一个分解问题，但要求换基矩阵是正交矩阵，依次回答三个问题：哪些实矩阵能在标准正交基下对角化；怎样求出并检验这种分解；特征值重复时，分解中的哪些部分仍由矩阵唯一确定。

第一个问题的答案是实对称矩阵，这就是谱定理。第二个问题给出计算路线和逐项核验的方法。第三个问题的答案是特征子空间和到它们的正交投影：特征基可以在重根空间内任意旋转，这些投影却不变；由它们还能直接读出对称矩阵的定号性。

对称矩阵之外的一般方阵留给下一节的 Schur 形。本节的谱分解还是后面几章的出发点：第 5章由它构造奇异值分解，第 6章由它开方；长度约束下的二次型极值与最佳低秩逼近则在第 15章讨论。

4.3.1 实对称矩阵的谱定理

特征方向互相垂直时，换基最简单。若 $\boldsymbol{q}_1,\dots,\boldsymbol{q}_d$ 是 $\mathbb{R}^d$ 的标准正交基，把它们排成正交矩阵 $\boldsymbol{Q}$，则 $\boldsymbol{Q}^{-1}=\boldsymbol{Q}^{\mathsf{T}}$。于是换基不必解方程：向量 $\boldsymbol{x}$ 的新坐标就是内积 $c_i=\boldsymbol{q}_i^{\mathsf{T}}\boldsymbol{x}$，长度也保持不变，$\|\boldsymbol{x}\|_2^2=\sum_i c_i^2$（第 3.5.2节）。所以，若 $\boldsymbol{S}\in\mathbb{R}^{d\times d}$ 能写成

$$\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathsf{T}},$$

其中 $\boldsymbol{Q}$ 为正交矩阵、$\boldsymbol{\Lambda}$ 为实对角矩阵，它的作用就最容易看清：先用内积读出各方向的坐标，再把第 i 个坐标乘以 λ_i，最后合回去。

哪些矩阵能这样写？先看必要条件。对上式取转置，由 $\boldsymbol{\Lambda}^{\mathsf{T}}=\boldsymbol{\Lambda}$ 得

$$\boldsymbol{S}^{\mathsf{T}}=(\boldsymbol{Q}^{\mathsf{T}})^{\mathsf{T}}\boldsymbol{\Lambda}^{\mathsf{T}}\boldsymbol{Q}^{\mathsf{T}}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathsf{T}}=\boldsymbol{S},$$

所以能用正交矩阵对角化的实矩阵必须对称。对称矩阵也就是第 3.6节的自伴映射在标准正交坐标下的矩阵：$\langle\boldsymbol{S}\boldsymbol{x},\boldsymbol{y}\rangle=\langle\boldsymbol{x},\boldsymbol{S}\boldsymbol{y}\rangle$ 对一切 $\boldsymbol{x},\boldsymbol{y}$ 成立。接下来的问题是：对称性是否也是充分的？本小节证明答案是肯定的。

证明的思路是：先找到一个实特征向量，再在与它垂直的子空间中重复这一步。第一步并不平凡。示例 4.2的旋转矩阵没有实特征向量，可见一般实矩阵的特征多项式可能没有实根；对称性的作用正是排除这种情形。

所用的工具是复数。由代数基本定理，d 次实系数多项式 $p_{\boldsymbol{S}}$ 在复数范围内至少有一个根 λ；第 4.4节将系统地把这些复根当作特征值，这里只用到其中一个。行列式的排列展开与消元只用到加、减、乘、除，对复数元素同样成立，所以 $\det(\lambda\boldsymbol{I}-\boldsymbol{S})=0$ 时，齐次方程 $(\lambda\boldsymbol{I}-\boldsymbol{S})\boldsymbol{z}=\boldsymbol{0}$ 有非零的复向量解 $\boldsymbol{z}\in\mathbb{C}^d$，即 $\boldsymbol{S}\boldsymbol{z}=\lambda\boldsymbol{z}$。

复向量需要另一种度量长度的方式，因为 $\boldsymbol{z}^{\top}\boldsymbol{z}=\sum_i z_i^2$ 可以是负数甚至非实数。这里用到复数的共轭：$z=a+\mathrm{i}b$ 的共轭为 $\bar z=a-\mathrm{i}b$，它满足 $\bar z z=a^2+b^2=|z|^2\ge 0$，等号仅在 $z=0$ 时成立；共轭与加法、乘法可交换，即 $\overline{z+w}=\bar z+\bar w$、$\overline{zw}=\bar z\bar w$。这些运算可参考卷一第 4 章“实数、复数与函数”。记 $\bar{\boldsymbol{z}}$ 为逐个坐标取共轭所得的向量，则

$$\bar{\boldsymbol{z}}^{\top}\boldsymbol{z}=\sum_{i=1}^{d}\bar z_i z_i=\sum_{i=1}^{d}|z_i|^2,$$

它是实数，且 $\boldsymbol{z}\neq\boldsymbol{0}$ 时为正。这个量称为 $\boldsymbol{z}$ 与自身的共轭内积；下面的证明靠它说明对称矩阵的 λ 必为实数。

确认 λ 为实数并取得实特征向量之后，再在正交补中重复，逐个找出互相正交的特征方向，就得到下面的结论，称为**谱定理**（spectral theorem）。

定理 4.21　谱定理　设 $\boldsymbol{S}\in\mathbb{R}^{d\times d}$ 满足 $\boldsymbol{S}=\boldsymbol{S}^{\top}$，则存在正交矩阵 $\boldsymbol{Q}=[\boldsymbol{q}_1,\dots,\boldsymbol{q}_d]$ 与实对角矩阵 $\boldsymbol{\Lambda}=\operatorname{diag}(\lambda_1,\dots,\lambda_d)$，使

$$\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\top},\qquad \boldsymbol{S}\boldsymbol{q}_i=\lambda_i\boldsymbol{q}_i\quad(i=1,\dots,d).\tag{4.4}$$

对任意 $\boldsymbol{x}=\sum_i c_i\boldsymbol{q}_i$，二次型展开为

$$\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}=\sum_{i=1}^{d}\lambda_i c_i^2.\tag{4.5}$$

证明　对维数 d 归纳。$d=1$ 时 $\boldsymbol{S}=[s_{1,1}]$，取 $\boldsymbol{Q}=[1]$、$\lambda_1=s_{1,1}$ 即可。设结论对 $d-1$ 阶实对称矩阵成立，下面分三步处理 d 阶的 $\boldsymbol{S}$。

第一步，特征值是实数。由定理前的讨论，存在复数 λ 与非零复向量 $\boldsymbol{z}$ 使 $\boldsymbol{S}\boldsymbol{z}=\lambda\boldsymbol{z}$。左乘 $\bar{\boldsymbol{z}}^{\top}$，得

$$\bar{\boldsymbol{z}}^{\top}\boldsymbol{S}\boldsymbol{z}=\lambda\,\bar{\boldsymbol{z}}^{\top}\boldsymbol{z}.$$

另一方面，$\boldsymbol{S}$ 的元素是实数，对 $\boldsymbol{S}\boldsymbol{z}=\lambda\boldsymbol{z}$ 逐坐标取共轭得 $\boldsymbol{S}\bar{\boldsymbol{z}}=\bar{\lambda}\bar{\boldsymbol{z}}$；再由 $\boldsymbol{S}^{\top}=\boldsymbol{S}$，

$$\bar{\boldsymbol{z}}^{\top}\boldsymbol{S}\boldsymbol{z}=(\boldsymbol{S}^{\top}\bar{\boldsymbol{z}})^{\top}\boldsymbol{z}=(\boldsymbol{S}\bar{\boldsymbol{z}})^{\top}\boldsymbol{z}=\bar{\lambda}\,\bar{\boldsymbol{z}}^{\top}\boldsymbol{z}.$$

两式相减得 $(\lambda-\bar{\lambda})\bar{\boldsymbol{z}}^{\top}\boldsymbol{z}=0$。由于 $\bar{\boldsymbol{z}}^{\top}\boldsymbol{z}=\sum_i|z_i|^2>0$，只能 $\lambda=\bar{\lambda}$，即 λ 是实数。

第二步，取得实特征向量。把 $\boldsymbol{z}$ 按实部、虚部写成 $\boldsymbol{z}=\boldsymbol{x}+\mathrm{i}\boldsymbol{y}$，其中 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^d$。$\boldsymbol{S}$ 与 λ 都是实的，比较 $\boldsymbol{S}\boldsymbol{x}+\mathrm{i}\,\boldsymbol{S}\boldsymbol{y}=\lambda\boldsymbol{x}+\mathrm{i}\,\lambda\boldsymbol{y}$ 两边的实部与虚部，得 $\boldsymbol{S}\boldsymbol{x}=\lambda\boldsymbol{x}$、$\boldsymbol{S}\boldsymbol{y}=\lambda\boldsymbol{y}$。$\boldsymbol{z}\neq\boldsymbol{0}$ 说明 $\boldsymbol{x}$ 与 $\boldsymbol{y}$ 不全为零，取其中非零的一个并单位化，记为 $\boldsymbol{q}_1$，记 $\lambda_1=\lambda$，则 $\boldsymbol{S}\boldsymbol{q}_1=\lambda_1\boldsymbol{q}_1$。

第三步，正交补不变并归纳。对 $\boldsymbol{h}\perp\boldsymbol{q}_1$，由对称性，

$$\boldsymbol{q}_1^{\top}(\boldsymbol{S}\boldsymbol{h})=(\boldsymbol{S}\boldsymbol{q}_1)^{\top}\boldsymbol{h}=\lambda_1\boldsymbol{q}_1^{\top}\boldsymbol{h}=0,$$

所以 $\boldsymbol{S}$ 把 $d-1$ 维子空间 $\boldsymbol{q}_1^{\perp}$ 映到自身。取 $\boldsymbol{q}_1^{\perp}$ 的一组标准正交基排成 $d\times(d-1)$ 矩阵 $\boldsymbol{U}$，则 $\boldsymbol{S}\boldsymbol{U}$ 的各列仍在 $\boldsymbol{q}_1^{\perp}$ 中，可以写成 $\boldsymbol{S}\boldsymbol{U}=\boldsymbol{U}\boldsymbol{S}'$，其中 $\boldsymbol{S}'=\boldsymbol{U}^{\top}\boldsymbol{S}\boldsymbol{U}$ 是 $d-1$ 阶实对称矩阵。由归纳假设，$\boldsymbol{S}'=\boldsymbol{Q}'\boldsymbol{\Lambda}'\boldsymbol{Q}'^{\top}$，$\boldsymbol{Q}'$ 为正交矩阵。令 $[\boldsymbol{q}_2,\dots,\boldsymbol{q}_d]=\boldsymbol{U}\boldsymbol{Q}'$，则这些列两两正交、长度为 1，都与 $\boldsymbol{q}_1$ 正交，且 $\boldsymbol{S}\boldsymbol{U}\boldsymbol{Q}'=\boldsymbol{U}\boldsymbol{S}'\boldsymbol{Q}'=\boldsymbol{U}\boldsymbol{Q}'\boldsymbol{\Lambda}'$，即 $\boldsymbol{S}\boldsymbol{q}_i=\lambda_i\boldsymbol{q}_i$ $(i=2,\dots,d)$，其中 $\lambda_2,\dots,\lambda_d$ 是 $\boldsymbol{\Lambda}'$ 的对角元。于是 $\boldsymbol{Q}=[\boldsymbol{q}_1,\dots,\boldsymbol{q}_d]$ 是正交矩阵，$\boldsymbol{S}\boldsymbol{Q}=\boldsymbol{Q}\boldsymbol{\Lambda}$，两边右乘 $\boldsymbol{Q}^{\top}$ 即得谱分解。

最后，把 $\boldsymbol{x}=\sum_i c_i\boldsymbol{q}_i$ 代入二次型：交叉项 $c_ic_j\boldsymbol{q}_i^{\top}\boldsymbol{S}\boldsymbol{q}_j=c_ic_j\lambda_j\boldsymbol{q}_i^{\top}\boldsymbol{q}_j$ 在 $i\neq j$ 时为零，只剩 $\sum_i\lambda_ic_i^2$。 ■

证明用到的是代数基本定理与对称性：前者保证复特征向量存在，后者先使特征值为实数，再使正交补在作用下不变。复数只在第一步出现，所得的 $\boldsymbol{Q}$ 与 $\boldsymbol{\Lambda}$ 都是实的。证明也没有用到二次型在单位球面上的极值；第 15章反过来由谱分解读出这些极值。同时交换 $\boldsymbol{\Lambda}$ 的对角元与 $\boldsymbol{Q}$ 的对应列，谱分解仍然成立，所以下文总把特征值排成 $\lambda_1\geq\lambda_2\geq\cdots\geq\lambda_d$。

对称性还直接给出不同特征方向之间的关系。设 $\boldsymbol{S}\boldsymbol{u}=\lambda\boldsymbol{u}$、$\boldsymbol{S}\boldsymbol{w}=\mu\boldsymbol{w}$，且 $\lambda\neq\mu$。由 $\boldsymbol{S}^{\top}=\boldsymbol{S}$，

$$\lambda\,\boldsymbol{u}^{\top}\boldsymbol{w}=(\boldsymbol{S}\boldsymbol{u})^{\top}\boldsymbol{w}=\boldsymbol{u}^{\top}(\boldsymbol{S}\boldsymbol{w})=\mu\,\boldsymbol{u}^{\top}\boldsymbol{w},$$

于是 $(\lambda-\mu)\boldsymbol{u}^{\top}\boldsymbol{w}=0$，只能 $\boldsymbol{u}^{\top}\boldsymbol{w}=0$。所以实对称矩阵属于不同特征值的特征空间互相正交。这一点不依赖谱定理中 $\boldsymbol{Q}$ 的具体选法，下一小节计算谱分解时会用到它。

4.3.2　谱分解的计算与核验

谱定理保证分解存在，但证明是逐步归纳的，没有直接给出计算步骤。

对手算规模的对称矩阵 $\boldsymbol{S}$，可以按以下次序求出 $\boldsymbol{Q}$ 与 $\boldsymbol{\Lambda}$。先解特征多项式 $p_{\boldsymbol{S}}(z)=0$，得到全部特征值；由谱定理，它们都是实数，按重数计共有 d 个。再对每个不同的特征值 λ 解齐次方程 $(\boldsymbol{S}-\lambda\boldsymbol{I})\boldsymbol{x}=\boldsymbol{0}$，得到特征空间 $\ker(\boldsymbol{S}-\lambda\boldsymbol{I})$ 的一组基。然后在每个特征空间内部做 Gram–Schmidt 正交化（定理 3.65）并单位化。最后把所有这样得到的向量排成 $\boldsymbol{Q}$ 的列，把对应的特征值按同样的顺序放到 $\boldsymbol{\Lambda}$ 的对角线上。

正交化只需在各特征空间内部进行。上一小节已经证明，不同特征值的特征空间互相正交，所以来自不同特征空间的向量自动垂直。重根空间则不同：解齐次方程得到的一组基通常不正交，必须在空间内部重新选择标准正交基。各特征空间的维数之和恰为 d，这同样由谱定理保证：$\boldsymbol{Q}$ 的 d 列按特征值分组，每组都落在相应的特征空间中。

算出 $\boldsymbol{Q}$ 与 $\boldsymbol{\Lambda}$ 之后，逐项核验两件事。其一是 $\boldsymbol{Q}^{\top}\boldsymbol{Q}=\boldsymbol{I}$，即各列单位长度且两两正交；它保证 $\boldsymbol{Q}^{-1}=\boldsymbol{Q}^{\top}$。其二是 $\boldsymbol{S}\boldsymbol{Q}=\boldsymbol{Q}\boldsymbol{\Lambda}$，逐列看就是 $\boldsymbol{S}\boldsymbol{q}_i=\lambda_i\boldsymbol{q}_i$；这一步同时检查了特征值与列向量的顺序是否一致。两项都成立时，右乘 $\boldsymbol{Q}^{\top}$ 即得 $\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\top}$。下面用一个二阶矩阵完成全过程。

示例 4.22　二阶对称矩阵的谱分解　按上面的次序求

$$\boldsymbol{S}=\begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix}$$

的谱分解，再做两项核验。

特征多项式为 $p_{\boldsymbol{S}}(z)=(z-2)^2-1=(z-3)(z-1)$，特征值为 3 与 1。解 $(\boldsymbol{S}-3\boldsymbol{I})\boldsymbol{x}=\boldsymbol{0}$ 得特征空间由 $(1,1)^{\top}$ 张成，解 $(\boldsymbol{S}-\boldsymbol{I})\boldsymbol{x}=\boldsymbol{0}$ 得特征空间由 $(1,-1)^{\top}$ 张成；这两个方向自动垂直，正如上一小节所证。两个特征值都是单根，各特征空间是一条直线，不必正交化，只需单位化：$\boldsymbol{q}_1=(1,1)^{\top}/\sqrt{2}$、$\boldsymbol{q}_2=(1,-1)^{\top}/\sqrt{2}$。于是

$$\boldsymbol{Q}=\frac{1}{\sqrt{2}}\begin{bmatrix}1 & 1\\ 1 & -1\end{bmatrix},\qquad \boldsymbol{\Lambda}=\begin{bmatrix}3 & 0\\ 0 & 1\end{bmatrix}.$$

先核验正交性：$\boldsymbol{Q}^{\top}\boldsymbol{Q}=\frac{1}{2}\left[\begin{smallmatrix}2 & 0\\ 0 & 2\end{smallmatrix}\right]=\boldsymbol{I}$。再核验特征关系：

$$\boldsymbol{S}\boldsymbol{Q}=\frac{1}{\sqrt{2}}\begin{bmatrix}3 & 1\\ 3 & -1\end{bmatrix}=\boldsymbol{Q}\boldsymbol{\Lambda},$$

第一列是 $3\boldsymbol{q}_1$，第二列是 $\boldsymbol{q}_2$，与 $\boldsymbol{\Lambda}$ 的对角顺序一致。两项都成立，所以 $\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\top}$：$\boldsymbol{S}$ 把 $(1,1)^{\top}$ 方向放大 3 倍，保持 $(1,-1)^{\top}$ 方向不变。

这个分解把 $\boldsymbol{S}$ 的作用拆成三步：$\boldsymbol{Q}^{\top}$ 把向量转到特征坐标，$\boldsymbol{\Lambda}$ 在两个坐标方向上分别伸缩 3 倍和 1 倍，$\boldsymbol{Q}$ 再转回来。$\boldsymbol{Q}$ 与 $\boldsymbol{Q}^{\top}$ 保持长度与夹角，改变形状的只有 $\boldsymbol{\Lambda}$。由于两个方向的伸缩倍数不同，整个作用 $\boldsymbol{S}$ 一般会改变向量间的夹角。例如 $\boldsymbol{e}_1$ 与 $\boldsymbol{e}_2$ 互相垂直，而 $\boldsymbol{S}\boldsymbol{e}_1=(2,1)^{\top}$ 与 $\boldsymbol{S}\boldsymbol{e}_2=(1,2)^{\top}$ 的内积为 4，夹角余弦为 $4/5$。只有特征方向之间的直角得以保持：$\boldsymbol{S}\boldsymbol{q}_1=3\boldsymbol{q}_1$ 与 $\boldsymbol{S}\boldsymbol{q}_2=\boldsymbol{q}_2$ 仍然垂直。

上述路线适合手算小矩阵。它要求写出特征多项式并求出全部根，阶数较高时这一步本身就难以手工完成；大规模矩阵的数值特征值算法不在本节讨论。无论 $\boldsymbol{Q}$ 与 $\boldsymbol{\Lambda}$ 由哪种方法得到，上面两项核验都只用到矩阵乘法，同样适用：两项都成立，就足以推出 $\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\top}$。

4.3.3 特征子空间与谱投影

特征值有重复时，$\boldsymbol{Q}$ 不唯一：重根空间内的任意一组标准正交基都可以作为这部分的列。本小节要回答，在这种不唯一之下，分解中哪些部分由 $\boldsymbol{S}$ 本身确定。为此先把 $\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\top}$ 按列展开，写成秩一矩阵之和：

$$\boldsymbol{S}=\sum_{i=1}^{d}\lambda_i\boldsymbol{q}_i\boldsymbol{q}_i^{\top}.$$

由式 (3.18)，$\boldsymbol{q}_i\boldsymbol{q}_i^{\top}$ 是到 $\boldsymbol{q}_i$ 方向的正交投影。例如示例 4.22中

$$\boldsymbol{S}=\frac{3}{2}\begin{bmatrix}1&1\\1&1\end{bmatrix}+\frac{1}{2}\begin{bmatrix}1&-1\\-1&1\end{bmatrix}.$$

单个 $\boldsymbol{q}_i$ 在重根空间中可以改变，所以单项 $\boldsymbol{q}_i\boldsymbol{q}_i^{\top}$ 也会随之改变。把同一特征值的各项合并，可以得到不再依赖这种选择的分解。

设 $\boldsymbol{S}$ 的不同特征值为 $\mu_1,\dots,\mu_m$（$m\le d$），特征空间为 $E_j=\ker(\boldsymbol{S}-\mu_j\boldsymbol{I})$。把 $\boldsymbol{Q}$ 中满足 $\lambda_i=\mu_j$ 的列排成矩阵 $\boldsymbol{Q}_j$，令 $\boldsymbol{P}_j=\boldsymbol{Q}_j\boldsymbol{Q}_j^{\top}$。

定理 4.23　谱投影　设 $\boldsymbol{S}\in\mathbb{R}^{d\times d}$ 对称，记号如上。则：

1. E_j 由 $\boldsymbol{Q}_j$ 的列张成，各 E_j 两两正交，且 $\sum_j\dim E_j=d$；
2. $\boldsymbol{P}_j$ 是到 E_j 的正交投影，满足 $\boldsymbol{P}_j\boldsymbol{P}_k=\boldsymbol{0}$（$j\neq k$）与 $\sum_{j=1}^{m}\boldsymbol{P}_j=\boldsymbol{I}$；
3. $\boldsymbol{S}=\sum_{j=1}^{m}\mu_j\boldsymbol{P}_j$；
4. E_j 与 $\boldsymbol{P}_j$ 只由 $\boldsymbol{S}$ 决定，与重根空间内标准正交基的选取无关。

证明　(1) 把任意 $\boldsymbol{x}$ 写成 $\boldsymbol{x}=\sum_i c_i\boldsymbol{q}_i$，则

$$(\boldsymbol{S}-\mu_j\boldsymbol{I})\boldsymbol{x}=\sum_{i=1}^{d} c_i(\lambda_i-\mu_j)\boldsymbol{q}_i.$$

$\boldsymbol{q}_i$ 线性无关，所以上式为零当且仅当 $\lambda_i\neq\mu_j$ 时 $c_i=0$，即 $\boldsymbol{x}$ 属于 $\boldsymbol{Q}_j$ 各列的张成。于是 $E_j=\operatorname{range}\boldsymbol{Q}_j$。不同的 $\boldsymbol{Q}_j$ 由 $\boldsymbol{Q}$ 的不同列组成，所以 E_j 两两正交；各 $\boldsymbol{Q}_j$ 的列数之和是 d，所以维数之和为 d。

(2)$\boldsymbol{Q}_j$ 的列是 E_j 的标准正交基，由式 (3.18)，$\boldsymbol{P}_j$ 是到 E_j 的正交投影。$j\neq k$ 时 $\boldsymbol{Q}_j^{\top}\boldsymbol{Q}_k=\boldsymbol{0}$，故 $\boldsymbol{P}_j\boldsymbol{P}_k=\boldsymbol{Q}_j(\boldsymbol{Q}_j^{\top}\boldsymbol{Q}_k)\boldsymbol{Q}_k^{\top}=\boldsymbol{0}$。把 $\boldsymbol{Q}\boldsymbol{Q}^{\top}=\sum_i\boldsymbol{q}_i\boldsymbol{q}_i^{\top}$ 的各项按特征值分组，得 $\sum_j\boldsymbol{P}_j=\boldsymbol{Q}\boldsymbol{Q}^{\top}=\boldsymbol{I}$。

(3) 在 $\boldsymbol{S}=\sum_i\lambda_i\boldsymbol{q}_i\boldsymbol{q}_i^{\top}$ 中，把 $\lambda_i=\mu_j$ 的项合并为 $\mu_j\boldsymbol{P}_j$ 即可。

(4)$E_j=\ker(\boldsymbol{S}-\mu_j\boldsymbol{I})$ 的定义只用到 $\boldsymbol{S}$。设 $\boldsymbol{Q}_j'$ 的列是 E_j 的另一组标准正交基，则每列都能用 $\boldsymbol{Q}_j$ 的列表示，即 $\boldsymbol{Q}_j'=\boldsymbol{Q}_j\boldsymbol{R}$，其中 $\boldsymbol{R}=\boldsymbol{Q}_j^{\top}\boldsymbol{Q}_j'$。由 $\boldsymbol{R}^{\top}\boldsymbol{R}=\boldsymbol{Q}_j'^{\top}\boldsymbol{Q}_j\boldsymbol{Q}_j^{\top}\boldsymbol{Q}_j'=\boldsymbol{Q}_j'^{\top}\boldsymbol{P}_j\boldsymbol{Q}_j'=\boldsymbol{Q}_j'^{\top}\boldsymbol{Q}_j'=\boldsymbol{I}$ 知 $\boldsymbol{R}$ 是正交方阵，于是 $\boldsymbol{R}\boldsymbol{R}^{\top}=\boldsymbol{I}$，

$$\boldsymbol{Q}_j'\boldsymbol{Q}_j'^{\top}=\boldsymbol{Q}_j\boldsymbol{R}\boldsymbol{R}^{\top}\boldsymbol{Q}_j^{\top}=\boldsymbol{Q}_j\boldsymbol{Q}_j^{\top}=\boldsymbol{P}_j.$$

这里 $\boldsymbol{P}_j\boldsymbol{Q}_j'=\boldsymbol{Q}_j'$ 是因为 $\boldsymbol{Q}_j'$ 的列已在 E_j 中，投影不改变它们。 ■

称 $\boldsymbol{P}_j$ 为 $\boldsymbol{S}$ 的**谱投影**（spectral projection）。定理说明，重根空间内基的选择只是同一个投影的不同写法。下面的例子在三阶矩阵上直接看到这一点，同时演示重根空间内部的正交化。

示例 4.24　重根空间的两组基　考虑

$$\boldsymbol{S}=\begin{bmatrix}2&1&1\\1&2&1\\1&1&2\end{bmatrix}=\boldsymbol{I}+\boldsymbol{1}\boldsymbol{1}^{\top},$$

其中 $\boldsymbol{1}=(1,1,1)^{\top}$。写成 $\boldsymbol{I}+\boldsymbol{1}\boldsymbol{1}^{\top}$ 以后，特征方向不必解方程就能看出来。

由 $\boldsymbol{S}\boldsymbol{1}=\boldsymbol{1}+3\boldsymbol{1}=4\boldsymbol{1}$，$\boldsymbol{1}$ 是特征值 4 的特征向量；对 $\boldsymbol{x}\perp\boldsymbol{1}$，$\boldsymbol{1}^{\top}\boldsymbol{x}=0$，所以 $\boldsymbol{S}\boldsymbol{x}=\boldsymbol{x}$。于是特征值为 4（单根）与 1（二重），$E_1$ 是平面 $x_1+x_2+x_3=0$。

解方程得到的这个平面的一组基 $(1,-1,0)^\top$、$(1,0,-1)^\top$ 并不正交，内积为 1，所以要在平面内部做 Gram–Schmidt 正交化，得到

$$\boldsymbol{q}_2 = \frac{1}{\sqrt{2}}\begin{bmatrix}1\\-1\\0\end{bmatrix}, \qquad \boldsymbol{q}_3 = \frac{1}{\sqrt{6}}\begin{bmatrix}1\\1\\-2\end{bmatrix}.$$

把两个秩一投影相加，

$$\boldsymbol{q}_2\boldsymbol{q}_2^\top + \boldsymbol{q}_3\boldsymbol{q}_3^\top = \frac{1}{3}\begin{bmatrix}2&-1&-1\\-1&2&-1\\-1&-1&2\end{bmatrix} = \boldsymbol{I} - \frac{1}{3}\mathbf{1}\mathbf{1}^\top.$$

若改从 $(1,0,-1)^\top$ 出发正交化，得到的是另一组标准正交基 $(1,0,-1)^\top/\sqrt{2}$ 与 $(1,-2,1)^\top/\sqrt{6}$，单个的 $\boldsymbol{q}_i\boldsymbol{q}_i^\top$ 都变了，相加后却仍是 $\boldsymbol{I} - \frac{1}{3}\mathbf{1}\mathbf{1}^\top$。

所以 E_1 上的谱投影是 $\boldsymbol{P}_1 = \boldsymbol{I} - \frac{1}{3}\mathbf{1}\mathbf{1}^\top$，不随平面内基的选择而变；单根 4 的谱投影是 $\boldsymbol{P}_4 = \frac{1}{3}\mathbf{1}\mathbf{1}^\top$，二者之和为 $\boldsymbol{I}$，并且 $\boldsymbol{S} = 4\boldsymbol{P}_4 + \boldsymbol{P}_1$，与定理 4.23一致。

谱分解还能直接回答一个已经出现过的问题：给定对称矩阵，怎样判断它是否半正定或正定？第 3.4.2.1节的定义要求检查所有 $\boldsymbol{x}$ 上的二次型。把 $\boldsymbol{x}$ 写成 $\boldsymbol{x} = \sum_i c_i\boldsymbol{q}_i$，由正交性，式 (4.5)把二次型化为 $\sum_i \lambda_i c_i^2$，交叉项全部消失，检查于是只剩下各特征值的符号。

定理 4.25　用特征值判定定号性　设 $\boldsymbol{S} \in \mathbb{R}^{d\times d}$ 对称，特征值为 $\lambda_1 \geq \cdots \geq \lambda_d$。则 $\boldsymbol{S} \succeq 0$ 当且仅当 $\lambda_d \geq 0$，即全部特征值非负；$\boldsymbol{S} \succ 0$ 当且仅当 $\lambda_d > 0$，即全部特征值为正。

证明　取谱分解 $\boldsymbol{S} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^\top$。必要性：取 $\boldsymbol{x} = \boldsymbol{q}_i$，由式 (4.5)，$\boldsymbol{q}_i^\top\boldsymbol{S}\boldsymbol{q}_i = \lambda_i$。若 $\boldsymbol{S} \succeq 0$，则每个 $\lambda_i \geq 0$；若 $\boldsymbol{S} \succ 0$，由 $\boldsymbol{q}_i \neq \mathbf{0}$ 得每个 $\lambda_i > 0$。

充分性：任取 $\boldsymbol{x} = \sum_i c_i\boldsymbol{q}_i$，则 $\sum_i c_i^2 = \|\boldsymbol{x}\|_2^2$。若全部 $\lambda_i \geq 0$，则 $\boldsymbol{x}^\top\boldsymbol{S}\boldsymbol{x} = \sum_i \lambda_i c_i^2 \geq 0$。若全部 $\lambda_i > 0$，则

$$\boldsymbol{x}^\top\boldsymbol{S}\boldsymbol{x} = \sum_{i=1}^{d}\lambda_i c_i^2 \geq \lambda_d\sum_{i=1}^{d} c_i^2 = \lambda_d\|\boldsymbol{x}\|_2^2,$$

$\boldsymbol{x} \neq \mathbf{0}$ 时右端为正。 ■

第 5章构造奇异值时就要用到这个判据：$\boldsymbol{A}^\top\boldsymbol{A}$ 半正定，所以它的特征值都非负，可以开平方。证明中的 $\boldsymbol{q}_i^\top\boldsymbol{S}\boldsymbol{q}_i = \lambda_i$ 只说明特征方向上的二次型值

等于特征值；在全部单位方向中哪个方向使二次型最大或最小，是另一个问题，留到第 15章用 Rayleigh 商讨论。

回顾本节：能用正交矩阵对角化的实矩阵恰好是对称矩阵，谱分解 $\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathsf{T}}$ 把它写成沿互相垂直方向的伸缩，并可按“求特征值、求特征空间、空间内正交化、组装并核验”的次序算出。特征基在重根空间内可以改变，但特征子空间和谱投影 $\boldsymbol{P}_j$ 由 $\boldsymbol{S}$ 唯一确定，$\boldsymbol{S}=\sum_j \mu_j \boldsymbol{P}_j$；二次型在特征坐标下没有交叉项，定号性由特征值的符号决定。

许多重要的方阵并不对称，例如平面旋转与示例 4.13的上三角矩阵 $\left[\begin{smallmatrix}0.8 & 4\\ 0 & 0.5\end{smallmatrix}\right]$。下一节讨论，用正交矩阵换基时，一般方阵能化到多简单。

4.4 一般方阵的 Schur 形

前两节的对角化各有前提：用可逆矩阵对角化，要求有足够多的实特征向量；用正交矩阵对角化，要求矩阵对称。不对称的方阵可能在两处不满足这些前提。其一，实特征值可能不够：平面上的 90° 旋转没有实特征向量，第 4.2节的对角化在第一步就停止。其二，即使可以对角化，特征向量也可能互不正交：示例 4.13中矩阵的两条特征方向 $(1,0)^{\mathsf{T}}$ 与 $(-40/3,1)^{\mathsf{T}}$ 夹角只有约 4.3°（计算见示例 4.27）。

本节分三步处理一般方阵。实特征值不够的问题，靠把特征多项式的复根也算作特征值来补救：一对共轭复特征值在实空间中对应一个不变平面，由此还得到谱半径。有了这些不变平面，就能证明用正交矩阵换基时，任何实方阵都能化为分块上三角的实 Schur 形。最后刻画 Schur 形何时是分块对角的，答案是正规矩阵；非正规矩阵的特征方向不正交，范数与谱半径可以相差很远。

4.4.1 复特征值与实不变平面

第 4.1.3节的特征多项式 $p_{\boldsymbol{A}}$ 是 d 次实系数多项式。由代数基本定理，它在复数范围内恰有 d 个根（计重数）。把这些根都称为 $\boldsymbol{A}$ 的特征值，全体特征值组成的集合称为 $\boldsymbol{A}$ 的**谱**（spectrum）。由于系数都是实数，若 $p_{\boldsymbol{A}}(\lambda)=0$，两边取共轭即得 $p_{\boldsymbol{A}}(\bar{\lambda})=0$，所以非实根成共轭对出现。实特征值的情形与第 4.1节相同。

第 4.1.4节由系数比较得到 $\operatorname{tr}\boldsymbol{A}=\sum_i \lambda_i$ 与 $\det\boldsymbol{A}=\prod_i \lambda_i$，那里要求 $p_{\boldsymbol{A}}$ 能分解为实一次因子。计入复特征值以后，$p_{\boldsymbol{A}}$ 在复数范围内总能分解为一次因子之积，同样的系数比较说明，这两个等式对每个方阵都成立。

下面看非实特征值在实空间中对应的作用。设 $\lambda=a+\mathrm{i}b$（$b\neq 0$）是特征值。复矩阵 $\boldsymbol{A}-\lambda\boldsymbol{I}$ 的行列式为零，所以有非零的复向量 $\boldsymbol{u}+\mathrm{i}\boldsymbol{w}$ 满足

$\boldsymbol{A}(\boldsymbol{u}+\mathrm{i}\boldsymbol{w})=(a+\mathrm{i}b)(\boldsymbol{u}+\mathrm{i}\boldsymbol{w})$，其中 $\boldsymbol{u},\boldsymbol{w}$ 为实向量。比较两边的实部与虚部，得

$$\boldsymbol{A}\boldsymbol{u}=a\boldsymbol{u}-b\boldsymbol{w}$$

$$\boldsymbol{A}\boldsymbol{w}=b\boldsymbol{u}+a\boldsymbol{w}.$$

这两个等式说明 $\operatorname{span}\{\boldsymbol{u},\boldsymbol{w}\}$ 在 $\boldsymbol{A}$ 下不变。这个子空间是二维的，即 $\boldsymbol{u},\boldsymbol{w}$ 线性无关。否则 $\boldsymbol{u},\boldsymbol{w}$（不全为零）只张成一条直线 $\operatorname{span}\{\boldsymbol{y}\}$，这条直线在 $\boldsymbol{A}$ 下不变，所以 $\boldsymbol{A}\boldsymbol{y}=\mu\boldsymbol{y}$，$\mu$ 为实数；而 $\boldsymbol{u}+\mathrm{i}\boldsymbol{w}$ 是 $\boldsymbol{y}$ 的复数倍，于是 $\boldsymbol{A}(\boldsymbol{u}+\mathrm{i}\boldsymbol{w})=\mu(\boldsymbol{u}+\mathrm{i}\boldsymbol{w})$，得 $\lambda=\mu$ 为实数，与 $b\neq 0$ 矛盾。所以 $\operatorname{span}\{\boldsymbol{u},\boldsymbol{w}\}$ 是二维实不变子空间。在基 $(\boldsymbol{u},\boldsymbol{w})$ 下，$\boldsymbol{A}$ 的作用由矩阵

$$\begin{bmatrix} a & b \\ -b & a \end{bmatrix}=|\lambda|\begin{bmatrix} \cos\phi & \sin\phi \\ -\sin\phi & \cos\phi \end{bmatrix}$$

$$\cos\phi=\frac{a}{|\lambda|},\ \sin\phi=\frac{b}{|\lambda|}$$

表示。在这组坐标中，它是 $|\lambda|$ 倍的伸缩加一次旋转。基 $(\boldsymbol{u},\boldsymbol{w})$ 一般不是标准正交基，所以这个坐标描述不能直接当作原空间中欧氏长度和角度的变化。

于是，特征值的模长 $|\lambda|$ 描述特征方向上或上述平面坐标中每次作用的倍率；它一般不是矩阵在欧氏范数下的一步最大放大倍数。全部特征值模长的最大值

$$\rho(\boldsymbol{A})=\max_i|\lambda_i(\boldsymbol{A})|$$

称为**谱半径**（spectral radius）。例如 90° 旋转的特征值为 $\pm\mathrm{i}$，谱半径为 1：它不改变长度，只改变方向。

4.4.2 实 Schur 分解

一般方阵未必能对角化，更未必能用正交矩阵对角化。退而求其次，可以用正交矩阵把它化为上三角形。上三角形同样便于计算：对角元就是特征值，解方程和求幂都可以从最后一个坐标逐个向前推。实特征值不够时，实上三角形不可能存在，因为它的对角元就是特征值，必须全是实数。但只要允许对角线上出现 2×2 块，这样的化简总能做到。

定理 4.26　实 Schur 形　对任意 $\boldsymbol{A}\in\mathbb{R}^{d\times d}$，存在正交矩阵 $\boldsymbol{Q}$ 与分块上三角矩阵 $\boldsymbol{T}$，使

$$\boldsymbol{A}=\boldsymbol{Q}\boldsymbol{T}\boldsymbol{Q}^{\top},\tag{4.6}$$

$\boldsymbol{T}$ 的对角块为 1×1（实特征值）或 2×2（一对共轭特征值），对角块下方全为零。$\boldsymbol{A}$ 的特征值就是各对角块的特征值。

证明　对 d 归纳：先找一个不变子空间，再把矩阵写成分块上三角形式，对右下角的压缩矩阵降维。这里一般不能假定该不变子空间的正交补也不变。若 $\boldsymbol{A}$ 有实特征值 λ，取单位特征向量 $\boldsymbol{q}_1$ 并扩充为正交矩阵 $\boldsymbol{Q}_1=[\boldsymbol{q}_1,\boldsymbol{Q}_2]$。由 $\boldsymbol{A}\boldsymbol{q}_1=\lambda\boldsymbol{q}_1$ 与 $\boldsymbol{Q}_2^{\top}\boldsymbol{q}_1=\boldsymbol{0}$，$\boldsymbol{Q}_1^{\top}\boldsymbol{A}\boldsymbol{Q}_1$ 的第一列为 $\lambda\boldsymbol{e}_1$，即

$$\boldsymbol{Q}_1^{\top}\boldsymbol{A}\boldsymbol{Q}_1=\begin{bmatrix}\lambda & * \\ \boldsymbol{0} & \boldsymbol{Q}_2^{\top}\boldsymbol{A}\boldsymbol{Q}_2\end{bmatrix}.$$

若没有实特征值，取上一小节得到的二维不变子空间，用它的一组标准正交基 $\boldsymbol{q}_1,\boldsymbol{q}_2$ 同样扩充，得到左上角为 2×2 块、其下方为零的分块形式，该块的特征值是 $\lambda,\bar{\lambda}$。分块上三角矩阵的特征多项式是对角块特征多项式之积，所以右下块的特征值恰为其余特征值。对右下块应用归纳假设，再把两次正交变换合并，即得结论。 ■

实际计算先用 Householder 反射化为上 Hessenberg 形，再作带位移的 QR 迭代，标准数值软件都提供这一分解；本卷只使用它的存在性。第 16.1.3节求解 Sylvester 方程时，用的正是这一形式。

4.4.3　正规矩阵与非正规矩阵

本小节确定 Schur 形何时是分块对角的，并说明不满足这一条件时会出现什么现象。

正规矩阵的分块对角形　实对称矩阵是一例。这时 $\boldsymbol{T}=\boldsymbol{Q}^{\top}\boldsymbol{A}\boldsymbol{Q}$ 仍对称，它的 2×2 对角块也对称，特征值为实数，不可能对应一对共轭特征值，所以 $\boldsymbol{T}$ 只有 1×1 对角块，是上三角矩阵。对称的上三角矩阵只能是对角矩阵，这又一次得到谱定理。

更一般地，第 3.6节把满足 $TT^{\star}=T^{\star}T$ 的算子称为正规算子。在标准坐标下伴随就是转置，满足 $\boldsymbol{A}^{\top}\boldsymbol{A}=\boldsymbol{A}\boldsymbol{A}^{\top}$ 的矩阵称为**正规矩阵**（normal matrix）；对称、反对称与正交矩阵都是正规的。

正规矩阵的 Schur 形 $\boldsymbol{T}$ 分块对角。首先 $\boldsymbol{T}$ 也正规：$\boldsymbol{T}^{\top}\boldsymbol{T}=\boldsymbol{Q}^{\top}\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{Q}=\boldsymbol{Q}^{\top}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{Q}=\boldsymbol{T}\boldsymbol{T}^{\top}$。比较 $\boldsymbol{T}^{\top}\boldsymbol{T}$ 与 $\boldsymbol{T}\boldsymbol{T}^{\top}$ 的左上角对角块：前者是 $\boldsymbol{T}_{1,1}^{\top}\boldsymbol{T}_{1,1}$，因为 $\boldsymbol{T}$ 的第一块列只有 $\boldsymbol{T}_{1,1}$ 非零；后者是 $\sum_j \boldsymbol{T}_{1,j}\boldsymbol{T}_{1,j}^{\top}$。两边取迹，得

$$\|\boldsymbol{T}_{1,1}\|_{\mathrm{F}}^2=\|\boldsymbol{T}_{1,1}\|_{\mathrm{F}}^2+\sum_{j>1}\|\boldsymbol{T}_{1,j}\|_{\mathrm{F}}^2,$$

故第一块行的非对角块全为零。去掉第一块后，剩下的矩阵仍正规，逐块推下去可知 $\boldsymbol{T}$ 分块对角。

每个 2×2 对角块 $\left[\begin{smallmatrix} p & q \\ r & s \end{smallmatrix}\right]$ 也正规。比较两边的 $(1,1)$ 元得 $q^2 = r^2$。若 $q = r$，块对称，特征值为实数，与 2×2 块对应一对共轭特征值矛盾；所以 $r = -q \neq 0$。再比较 $(1,2)$ 元得 $2q(s-p) = 0$，即 $s = p$。于是每块都形如

$$\begin{bmatrix} a & b \\ -b & a \end{bmatrix},$$

是模长乘旋转。反过来，若正交矩阵 $\boldsymbol{Q}$ 把 $\boldsymbol{A}$ 化为分块对角矩阵 $\boldsymbol{T}$，且每块是一个数或这种模长乘旋转的块，则每块与自己的转置可交换，$\boldsymbol{T}^{\top}\boldsymbol{T} = \boldsymbol{T}\boldsymbol{T}^{\top}$，从而 $\boldsymbol{A} = \boldsymbol{Q}\boldsymbol{T}\boldsymbol{Q}^{\top}$ 正规。所以正规矩阵恰好是能用标准正交基化为这种分块对角形的实方阵。

因此，正规矩阵沿一组标准正交的方向或平面只作伸缩，或伸缩加旋转。$\boldsymbol{T}^k$ 仍分块对角，每块是 λ^k 或 $|\lambda|^k$ 乘一个旋转，二范数为 $|\lambda|^k$；正交变换又不改变谱范数，所以 $\|\boldsymbol{A}^k\|_2 = \|\boldsymbol{T}^k\|_2 = \max_i |\lambda_i|^k = \rho(\boldsymbol{A})^k$。也就是说，正规矩阵每一步的最大放大倍数恰好就是谱半径。

非正规矩阵 由上面的刻画，非正规矩阵的 Schur 形 $\boldsymbol{T}$ 不可能是由数与模长乘旋转块组成的分块对角形：它要么含非零的非对角块，要么某个 2×2 对角块本身不正规。非正规矩阵也不能用一组标准正交的特征向量对角化，否则它对称。这时矩阵范数可以远大于谱半径，下面的例子显示了这种分离。

示例 4.27　非正规矩阵的范数与谱半径　回到示例 4.13的矩阵

$$\boldsymbol{A} = \begin{bmatrix} 0.8 & 4 \\ 0 & 0.5 \end{bmatrix}.$$

那里求幂时，$\boldsymbol{A}^k$ 按 0.8^k 与 0.5^k 衰减；现在看一步作用能把向量放大多少，以及这与特征方向的几何位置有什么关系。

先确认它不正规：$\boldsymbol{A}^{\top}\boldsymbol{A}$ 的 $(1,1)$ 元为 $0.8^2 = 0.64$，$\boldsymbol{A}\boldsymbol{A}^{\top}$ 的 $(1,1)$ 元为 $0.8^2 + 4^2 = 16.64$，二者不等。特征值为 0.8 与 0.5，所以 $\rho(\boldsymbol{A}) = 0.8$。然而一步作用把单位向量 $(0,1)^{\top}$ 送到 $(4, 0.5)^{\top}$，长度为 $\sqrt{16.25} > 4$，所以 $\|\boldsymbol{A}\|_2 > 4$，超过谱半径的五倍。

差距来自特征方向的位置。两条特征方向 $\boldsymbol{v}_1 = (1,0)^{\top}$ 与 $\boldsymbol{v}_2 = (-40/3, 1)^{\top}$ 的夹角 θ 满足

$$\cos\theta = \frac{|\boldsymbol{v}_1^{\top}\boldsymbol{v}_2|}{\|\boldsymbol{v}_1\|_2\|\boldsymbol{v}_2\|_2} = \frac{40/3}{\sqrt{(40/3)^2 + 1}} \approx 0.997,$$

即 $\theta \approx 4.3°$，两条特征方向几乎平行。$(0,1)^{\mathsf{T}}$ 这样的向量拆到特征方向上，要用两个很大且符号相反的分量 $\frac{40}{3}\boldsymbol{v}_1$ 与 $\boldsymbol{v}_2$ 相互抵消；作用一次后两个分量按不同倍数缩小，抵消不再完全，结果就变得很长。所以谱半径只有 0.8，一步的最大放大倍数却超过 4。

谱半径描述反复作用的长期倍率，范数描述一步的最大放大；非正规时二者可以分离。第 8.4节将看到，这种分离可能伴随先放大、后衰减的瞬态。

回顾本节：实矩阵的特征值可能是复数，一对共轭特征值 $a \pm \mathrm{i}b$ 对应一个二维不变平面，在其中某组基下的坐标中作伸缩加旋转；谱半径 $\rho(\boldsymbol{A})$ 概括每作用一次的长期伸缩倍数。用标准正交基换基时，一般方阵只能化为实 Schur 形。恰好能化为由数与模长乘旋转块组成的分块对角形的是正规矩阵，它每一步的最大放大等于谱半径；非正规矩阵的范数与谱半径则可能相差悬殊。

这些结论都要求矩阵把空间映到自身，并且输入、输出用同一组基。第 5章允许两端各取一组标准正交基，这时任何矩阵都能化为对角形。

4.5 本章小结

本章开头问：给定方阵，在什么样的基下它最简单？答案取决于对基提出什么要求。三种要求依次加强，能达到的形式也依次退让。

只要求换基矩阵可逆时，目标是对角形。被作用只伸缩的方向是特征向量，特征值是特征多项式 $p_{\boldsymbol{A}}(z) = \det(z\boldsymbol{I} - \boldsymbol{A})$ 的根，与基的选取无关；Cayley–Hamilton 定理说明 $p_{\boldsymbol{A}}(\boldsymbol{A}) = \boldsymbol{0}$，所以 $\boldsymbol{A}$ 的高次幂都能用前 n 个幂表示。

n 阶矩阵实可对角化，当且仅当它有 n 个线性无关的实特征向量；等价地，特征多项式分解为实一次因子，且每个特征值的几何重数等于代数重数。这时 $\boldsymbol{A}^k = \boldsymbol{V}\boldsymbol{\Lambda}^k\boldsymbol{V}^{-1}$，反复作用化为特征值的乘方。失败有两种方式：实特征值不够，如平面旋转；特征向量不够，如 $\left[\begin{smallmatrix} 0.8 & 1 \\ 0 & 0.8 \end{smallmatrix}\right]$，其幂含有随 k 增长的多项式因子。

要求换基矩阵正交时，特征基还必须两两垂直。能这样对角化的实矩阵恰好是对称矩阵，谱分解 $\boldsymbol{S} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathsf{T}}$ 把作用写成沿互相垂直方向的伸缩。重特征值对应的特征向量可以在特征空间内任意旋转，但特征空间和谱投影由 $\boldsymbol{S}$ 唯一确定，$\boldsymbol{S} = \sum_j \mu_j \boldsymbol{P}_j$；二次型在特征坐标下没有交叉项，所以定号性由特征值的符号决定。

对一般方阵，正交换基只能退到分块上三角的实 Schur 形：一阶对角块对应实特征值，二阶对角块对应一对共轭复特征值及其实不变平面。Schur

形能取成分块对角的恰好是正规矩阵；这时每一步的最大放大倍数等于谱半径 $\rho(\boldsymbol{A})$。非正规矩阵的特征方向不正交，即使可以对角化，一步的放大倍数也可能远大于谱半径。

因此，特征方向不足时，应退到 Schur 形这类三角化表示；特征方向足够但不正交时，可逆换基仍能对角化，但长度和夹角在新坐标中失真，范数与谱半径也可能分离。第 7章将看到，这种不正交还使特征值对扰动更敏感；第 8章将看到，它可能使反复作用先放大、再衰减。

本章的所有分解都把空间映到自身，并让输入和输出共用一组基。矩形矩阵和非正规方阵都需要另一种表示：第 5章让输入、输出各取一组标准正交基，构造对任何矩阵都存在的奇异值分解。

第 5 章

奇异值分解

第 4章的分解都让输入与输出使用同一组基。在这一要求下用标准正交基换基，只有对称矩阵能化为实对角形，正规矩阵能化为分块对角形，一般方阵只能化为分块上三角的实 Schur 形。矩形矩阵 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$ 的输入在 $\mathbb{R}^d$ 中、输出在 $\mathbb{R}^m$ 中，“同一组基”与特征向量都无从谈起。

本章放宽这一要求，在输入端和输出端各取一组标准正交基。要回答的问题是：这样是否对任意矩阵都能得到对角形？对角元和两组基中哪些由矩阵唯一确定？从这种表示能直接读出矩阵的哪些大小？

第 5.1节先说明为什么要求两组基都标准正交，并写出目标形式。第 5.2节用对称矩阵 $\boldsymbol{A}^{\mathsf{T}}\boldsymbol{A}$ 的谱分解构造这两组基，整理分解的几种写法，再确定其中的唯一部分与可变部分。第 5.3节在奇异坐标中比较输出长度，读出谱范数、Frobenius 范数、秩与最弱的放大倍数。第 5.4节说明怎样核验一组因子，并用单位球的像解释分解。

本章只依赖第 4章的谱定理与定号性判据，以及第 3章的标准正交基与矩阵范数。由奇异向量选出最佳低秩近似、以及 Rayleigh 商的极值性质，在第 15章讨论；第 6章用本章的分解处理奇异矩阵和矩形矩阵的极分解。

5.1 输入与输出的正交坐标

先回忆换基怎样改变一个线性映射的矩阵。设 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$ 表示映射 $\boldsymbol{x} \mapsto \boldsymbol{A}\boldsymbol{x}$。按第 2.3.1节的约定，若在输入空间 $\mathbb{R}^d$ 中取新基并排成可逆矩阵 $\boldsymbol{V}$，在输出空间 $\mathbb{R}^m$ 中取新基并排成可逆矩阵 $\boldsymbol{U}$，则新坐标下的矩阵为 $\boldsymbol{U}^{-1}\boldsymbol{A}\boldsymbol{V}$：先由 $\boldsymbol{V}$ 把输入的新坐标换成标准坐标，作用 $\boldsymbol{A}$，再由 $\boldsymbol{U}^{-1}$ 读出输出的新坐标。方阵的相似变换 $\boldsymbol{P}^{-1}\boldsymbol{A}\boldsymbol{P}$ 是 $\boldsymbol{U}=\boldsymbol{V}=\boldsymbol{P}$ 的特殊情形。

两端可以独立换基，自由度就大得多。若 $\boldsymbol{U}$、$\boldsymbol{V}$ 只要求可逆，任何矩阵都能化成只含 0 与 1 的形式。设 $r=\operatorname{rank}\boldsymbol{A}$，取 $\ker\boldsymbol{A}$ 的一组基 $\boldsymbol{v}_{r+1},\dots,\boldsymbol{v}_d$，扩充成 $\mathbb{R}^d$ 的基 $\boldsymbol{v}_1,\dots,\boldsymbol{v}_d$。则 $\boldsymbol{A}\boldsymbol{v}_1,\dots,\boldsymbol{A}\boldsymbol{v}_r$ 线性无关：若 $\sum_{i\le r} c_i\boldsymbol{A}\boldsymbol{v}_i=\boldsymbol{0}$，

则 $\sum_{i\le r} c_i \boldsymbol{v}_i \in \ker \boldsymbol{A}$，它又是 $\boldsymbol{v}_{r+1}, \dots, \boldsymbol{v}_d$ 的组合，由全体 $\boldsymbol{v}_i$ 线性无关得各 $c_i = 0$。把这 r 个向量扩充成 $\mathbb{R}^m$ 的基并排成 $\boldsymbol{U}$，就有

$$\boldsymbol{U}^{-1}\boldsymbol{A}\boldsymbol{V} = \begin{bmatrix} \boldsymbol{I}_r & \boldsymbol{0} \\ \boldsymbol{0} & \boldsymbol{0} \end{bmatrix}.$$

这个形式只记录了秩。所有长度信息都被可逆换基吸收掉了，因为一般的可逆矩阵不保持长度。

因此我们要求两组基都标准正交，即 $\boldsymbol{U} \in \mathbb{R}^{m\times m}$ 与 $\boldsymbol{V} \in \mathbb{R}^{d\times d}$ 都是正交矩阵。这时 $\boldsymbol{U}^{-1} = \boldsymbol{U}^{\top}$，读坐标只需取内积，而且两端的换基都不改变长度和夹角，变换后的对角元才能表示真正的伸缩倍数。目标形式是 $\boldsymbol{U}^{\top}\boldsymbol{A}\boldsymbol{V} = \boldsymbol{\Sigma}$，其中 $\boldsymbol{\Sigma} \in \mathbb{R}^{m\times d}$ 只在 (i,i) 位置上可能非零。逐列写出，就是在输入端找标准正交方向 $\boldsymbol{v}_i$，在输出端找标准正交方向 $\boldsymbol{u}_i$，使

$$\boldsymbol{A}\boldsymbol{v}_i = \sigma_i \boldsymbol{u}_i, \qquad \sigma_i \ge 0,$$

其中 i 取 $1, \dots, \min(m,d)$。也就是说，$\boldsymbol{A}$ 把第 i 个输入方向伸缩 σ_i 倍后送到第 i 个输出方向；若输入维数更大，多出的输入基向量还须映到零。

伸缩倍数可以要求非负。若某个对角元为负，把对应的 $\boldsymbol{u}_i$ 换成 $-\boldsymbol{u}_i$，输出端仍是标准正交基，而对角元变号。正交矩阵的行列式为 ± 1，几何上是旋转，或者旋转再加一次反射，例如 $\mathrm{diag}(1,-1)$ 把平面关于第一坐标轴翻转。所以本章所说的输入、输出“转向”可以包含反射，不一概是纯旋转。

这一要求与特征分解的要求不同。特征分解要求 $\boldsymbol{A}\boldsymbol{v}$ 与 $\boldsymbol{v}$ 在同一条直线上，现在只要求被送到另一组标准正交方向中的对应一个。因此它对矩形矩阵有意义，对第 4章中不能对角化的 $\left[\begin{smallmatrix} 0.8 & 1 \\ 0 & 0.8 \end{smallmatrix}\right]$ 和特征方向几乎平行的 $\left[\begin{smallmatrix} 0.8 & 4 \\ 0 & 0.5 \end{smallmatrix}\right]$ 也有意义。对称矩阵则提供了现成的例子：若 $\boldsymbol{S} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\top}$，取 $\boldsymbol{v}_i = \boldsymbol{q}_i$、$\sigma_i = |\lambda_i|$，并在 $\lambda_i \ge 0$ 时取 $\boldsymbol{u}_i = \boldsymbol{q}_i$、在 $\lambda_i < 0$ 时取 $\boldsymbol{u}_i = -\boldsymbol{q}_i$，就满足上面的要求。半正定时两组基相同，有负特征值时输出端的相应方向反号。

5.2 奇异值分解的构造

先看这样的方向若存在，应当满足什么条件。设 $\boldsymbol{x} = \sum_i c_i \boldsymbol{v}_i$，则 $\boldsymbol{A}\boldsymbol{x} = \sum_i c_i \sigma_i \boldsymbol{u}_i$，由 $\boldsymbol{u}_i$ 标准正交，

$$\boldsymbol{x}^{\top}\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{x} = \|\boldsymbol{A}\boldsymbol{x}\|_2^2 = \sum_i \sigma_i^2 c_i^2.$$

与二次型展开式 (4.5)比较可知，$\boldsymbol{v}_i$ 应是对称矩阵 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 的特征向量，σ_i^2 是对应的特征值。所以构造从 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 出发。

令 $\boldsymbol{S} = \boldsymbol{A}^{\top}\boldsymbol{A}$。它对称，而且半正定：$\boldsymbol{x}^{\top}\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{x} = \|\boldsymbol{A}\boldsymbol{x}\|_2^2 \geq 0$。由谱定理（定理 4.21）与定号性判据（定理 4.25），存在 $\mathbb{R}^d$ 的标准正交基 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_d$ 使 $\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{v}_i = \lambda_i \boldsymbol{v}_i$，且 $\lambda_1 \geq \cdots \geq \lambda_d \geq 0$。设前 r 个特征值为正，记 $\sigma_i = \sqrt{\lambda_i} > 0$（$i \leq r$）。其余的 $\boldsymbol{v}_j$ 满足 $\|\boldsymbol{A}\boldsymbol{v}_j\|_2^2 = \boldsymbol{v}_j^{\top}\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{v}_j = 0$，即 $\boldsymbol{A}\boldsymbol{v}_j = \boldsymbol{0}$。

对 $i \leq r$ 定义输出方向 $\boldsymbol{u}_i = \boldsymbol{A}\boldsymbol{v}_i / \sigma_i$。它们标准正交：

$$\boldsymbol{u}_i^{\top}\boldsymbol{u}_j = \frac{\boldsymbol{v}_i^{\top}\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{v}_j}{\sigma_i \sigma_j} = \frac{\sigma_j^2\, \boldsymbol{v}_i^{\top}\boldsymbol{v}_j}{\sigma_i \sigma_j} = \delta_{i,j}.$$

再把 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_r$ 扩充为 $\mathbb{R}^m$ 的标准正交基 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_m$。这一步处理的是零奇异值：输出端多出的方向不是任何输入的像，只需与已有方向正交。

有了两组方向，就可以写出 $\boldsymbol{A}$ 的作用。把任意 $\boldsymbol{x}$ 展开为 $\boldsymbol{x} = \sum_i (\boldsymbol{v}_i^{\top}\boldsymbol{x})\boldsymbol{v}_i$，再利用 $\boldsymbol{A}\boldsymbol{v}_i = \sigma_i \boldsymbol{u}_i$（$i \leq r$）与 $\boldsymbol{A}\boldsymbol{v}_j = \boldsymbol{0}$（$j > r$），得

$$\boldsymbol{A}\boldsymbol{x} = \sum_{i=1}^{r} \sigma_i \boldsymbol{u}_i (\boldsymbol{v}_i^{\top}\boldsymbol{x}).$$

这对所有 $\boldsymbol{x}$ 成立，所以 $\boldsymbol{A}$ 是 r 个秩一矩阵之和：

$$\boldsymbol{A} = \sum_{i=1}^{r} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^{\top}. \tag{5.1}$$

由这个和式可以读出两个子空间。$\operatorname{range}(\boldsymbol{A})$ 由 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_r$ 张成；又因为 $\boldsymbol{u}_i$ 线性无关且 $\sigma_i > 0$，$\boldsymbol{A}\boldsymbol{x} = \boldsymbol{0}$ 当且仅当 $\boldsymbol{v}_i^{\top}\boldsymbol{x} = 0$（$i \leq r$），所以 $\ker \boldsymbol{A}$ 由 $\boldsymbol{v}_{r+1}, \dots, \boldsymbol{v}_d$ 张成。于是 $r = \operatorname{rank} \boldsymbol{A}$。把这些向量排成矩阵，就得到下面的结论。

定理 5.1　SVD 的存在　对任意 $\boldsymbol{A} \in \mathbb{R}^{m \times d}$，存在正交矩阵 $\boldsymbol{U} \in \mathbb{R}^{m \times m}$、$\boldsymbol{V} \in \mathbb{R}^{d \times d}$ 与对角矩阵 $\boldsymbol{\Sigma} \in \mathbb{R}^{m \times d}$，使 $\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$；$\boldsymbol{\Sigma}$ 的对角元 $\sigma_1 \geq \cdots \geq \sigma_{\min(m,d)} \geq 0$，其中恰有 $\operatorname{rank} \boldsymbol{A}$ 个为正。

定理中的 $\boldsymbol{\Sigma}$ 与 $\boldsymbol{A}$ 形状相同，“对角”指只有 (i, i) 位置的元素可能非零。这种分解有专门的名称。

定义 5.2　奇异值分解　称

$$\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top} \tag{5.2}$$

为 $\boldsymbol{A}$ 的**奇异值分解**（singular value decomposition, SVD），$\boldsymbol{\Sigma}$ 的对角元 σ_i 称为**奇异值**（singular value），$\boldsymbol{U}$、$\boldsymbol{V}$ 的列 $\boldsymbol{u}_i$、$\boldsymbol{v}_i$ 分别称为**左、右奇异向量**（singular vector）。

图 5.1把构造拆成三步：形成 $\boldsymbol{A}^{\top}\boldsymbol{A}$；由谱定理将其对角化；开方得到奇异值，再由 $\boldsymbol{u}_i = \boldsymbol{A}\boldsymbol{v}_i/\sigma_i$ 得到左奇异向量。

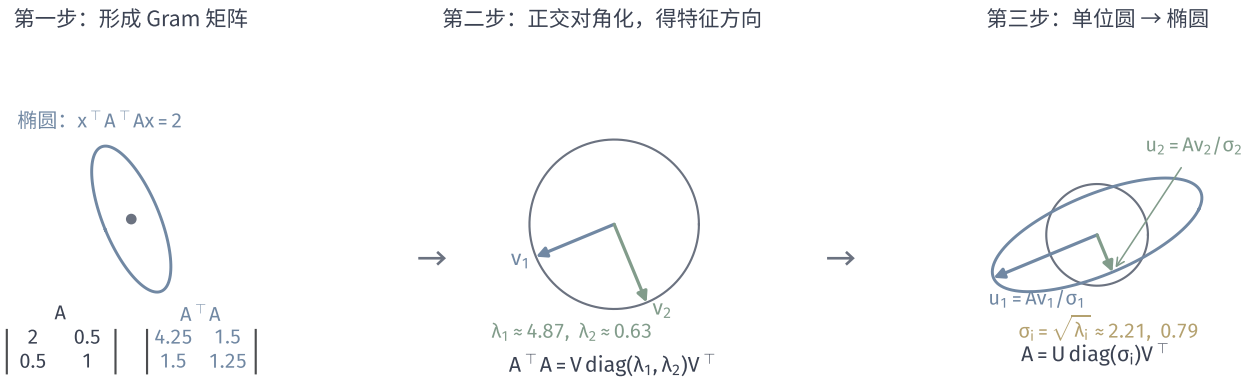


图 5.1　SVD 的三步构造。以 $\boldsymbol{A} = \left[\begin{smallmatrix} 2 & 0.5 \\ 0.5 & 1 \end{smallmatrix}\right]$ 为例：(1) 形成 $\boldsymbol{A}^{\top}\boldsymbol{A} = \left[\begin{smallmatrix} 4.25 & 1.5 \\ 1.5 & 1.25 \end{smallmatrix}\right]$；(2) 由谱定理对角化，特征值 $\lambda_1 \approx 4.87, \lambda_2 \approx 0.63$；(3)$\sigma_i = \sqrt{\lambda_i} \approx 2.21, 0.79$，右奇异向量 $\boldsymbol{v}_i$ 即特征向量，左奇异向量 $\boldsymbol{u}_i = \boldsymbol{A}\boldsymbol{v}_i/\sigma_i$。解析式教学构造。

左奇异向量与输出端也有对称的关系。对 $i \le r$，$\boldsymbol{A}^{\top}\boldsymbol{u}_i = \boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{v}_i/\sigma_i = \sigma_i\boldsymbol{v}_i$；对 $i > r$，$\boldsymbol{u}_i$ 与 $\operatorname{range}(\boldsymbol{A})$ 正交，故对任意 $\boldsymbol{x}$ 有 $(\boldsymbol{A}^{\top}\boldsymbol{u}_i)^{\top}\boldsymbol{x} = \boldsymbol{u}_i^{\top}\boldsymbol{A}\boldsymbol{x} = 0$，即 $\boldsymbol{A}^{\top}\boldsymbol{u}_i = \boldsymbol{0}$。于是

$$\boldsymbol{A}^{\top}\boldsymbol{u}_i = \sigma_i\boldsymbol{v}_i, \qquad \boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{u}_i = \sigma_i^2\boldsymbol{u}_i \qquad (i \le r), \tag{5.3}$$

而 $i > r$ 时 $\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{u}_i = \boldsymbol{0}$。也就是说，$\boldsymbol{u}_1, \dots, \boldsymbol{u}_m$ 是 $\boldsymbol{A}\boldsymbol{A}^{\top}$ 的一组标准正交特征向量，特征值依次为 $\sigma_1^2, \dots, \sigma_r^2$ 与 $m - r$ 个零。$\boldsymbol{A}^{\top}\boldsymbol{A}$ 与 $\boldsymbol{A}\boldsymbol{A}^{\top}$ 因而有相同的正特征值，分别在输入端与输出端给出奇异方向。

构造路线只用于证明存在性，并不意味着数值计算应当显式形成 $\boldsymbol{A}^{\top}\boldsymbol{A}$；这一点在第 5.4节说明。

5.2.1 奇异值分解的形式

定理 5.1中的 $\boldsymbol{U}$、$\boldsymbol{V}$ 都是方阵，这是完整分解，它同时给出两端的全部正交方向：$\boldsymbol{v}_{r+1}, \dots, \boldsymbol{v}_d$ 张成 $\ker \boldsymbol{A}$，$\boldsymbol{u}_{r+1}, \dots, \boldsymbol{u}_m$ 张成 $\operatorname{range}(\boldsymbol{A})$ 的正交补。三个因子的形状依次为 $m \times m$、$m \times d$ 与 $d \times d$。

许多计算只用到前 $p = \min(m, d)$ 列。令 $\boldsymbol{U}_p = [\boldsymbol{u}_1, \dots, \boldsymbol{u}_p] \in \mathbb{R}^{m \times p}$、$\boldsymbol{V}_p = [\boldsymbol{v}_1, \dots, \boldsymbol{v}_p] \in \mathbb{R}^{d \times p}$、$\boldsymbol{\Sigma}_p = \operatorname{diag}(\sigma_1, \dots, \sigma_p) \in \mathbb{R}^{p \times p}$，则

$$\boldsymbol{A} = \boldsymbol{U}_p\boldsymbol{\Sigma}_p\boldsymbol{V}_p^{\top},$$

称为**薄奇异值分解**（thin SVD），也称经济型分解。它由完整分解删去 $\boldsymbol{\Sigma}$ 中全为零的那些行或列，连同与之相乘的 $\boldsymbol{U}$ 或 $\boldsymbol{V}$ 的列得到，乘积不变。$m \geq d$ 时删去的是 $\boldsymbol{U}$ 的后 $m-d$ 列，$m < d$ 时删去的是 $\boldsymbol{V}$ 的后 $d-m$ 列。

若只保留正奇异值，令 $\boldsymbol{U}_r$、$\boldsymbol{V}_r$ 分别由前 r 个左、右奇异向量组成，$\boldsymbol{\Sigma}_r = \operatorname{diag}(\sigma_1, \dots, \sigma_r)$，则

$$\boldsymbol{A} = \boldsymbol{U}_r \boldsymbol{\Sigma}_r \boldsymbol{V}_r^{\top}, \qquad \boldsymbol{U}_r \in \mathbb{R}^{m\times r},\ \boldsymbol{\Sigma}_r \in \mathbb{R}^{r\times r},\ \boldsymbol{V}_r \in \mathbb{R}^{d\times r},$$

这就是和式 (5.1)的矩阵写法，称为秩分解形式。

三种写法给出同一个矩阵，区别在于是否保留零伸缩的方向。秩分解只描述 $\boldsymbol{A}$ 真正起作用的 r 对方向，$\boldsymbol{U}_r$ 与 $\boldsymbol{V}_r$ 只是列标准正交，不再是方阵；零空间与输出端正交补的基要从完整分解中读取。薄分解在 $r < p$ 时仍保留奇异值为零的列。三者都是 $\boldsymbol{A}$ 的精确表示；只保留前 $k < r$ 项、从而改变矩阵的截断近似，在第 15章讨论。

5.2.2 奇异值分解的唯一性

构造中有两处选择：$\boldsymbol{A}^{\top}\boldsymbol{A}$ 的标准正交特征基怎样选，以及输出端怎样补全。所以奇异值分解一般不唯一。本小节确定哪些部分由 $\boldsymbol{A}$ 唯一决定。

先看奇异值。设 $\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$ 是任意一个满足定理 5.1的分解，则 $\boldsymbol{A}^{\top}\boldsymbol{A} = \boldsymbol{V}(\boldsymbol{\Sigma}^{\top}\boldsymbol{\Sigma})\boldsymbol{V}^{\top}$，其中 $\boldsymbol{\Sigma}^{\top}\boldsymbol{\Sigma}$ 是 d 阶对角矩阵，对角元为 $\sigma_1^2, \dots, \sigma_{\min(m,d)}^2$，$d > m$ 时再补 $d-m$ 个零。$\boldsymbol{V}^{\top} = \boldsymbol{V}^{-1}$，所以 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 与 $\boldsymbol{\Sigma}^{\top}\boldsymbol{\Sigma}$ 相似。由定理 4.8，二者有相同的特征多项式，σ_i^2 连同重数恰是 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 的特征值。

$\boldsymbol{A}^{\top}\boldsymbol{A}$ 只依赖 $\boldsymbol{A}$，而 σ_i 是这些特征值降序排列后的非负平方根，因此与分解的选取无关：正奇异值是 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 正特征值的平方根，其余为零。

奇异向量则可以变化。最简单的变化是把一对 $\boldsymbol{u}_i, \boldsymbol{v}_i$ 同时变号：乘积 $\sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^{\top}$ 不变，两组向量仍各自标准正交。奇异值重复时变化更多，例如 $\boldsymbol{A} = \boldsymbol{I}_2$ 的奇异值都是 1，对任意正交矩阵 $\boldsymbol{R}$，$\boldsymbol{I}_2 = \boldsymbol{R}\boldsymbol{I}_2\boldsymbol{R}^{\top}$ 都是奇异值分解。但两端不能各自独立地换：$\boldsymbol{R}_1\boldsymbol{I}_2\boldsymbol{R}_2^{\top} = \boldsymbol{I}_2$ 迫使 $\boldsymbol{R}_1 = \boldsymbol{R}_2$。下面的定理说明，这些例子已经包括了全部的自由度。

定理 5.3　奇异值分解的唯一性范围　设 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$，$r = \operatorname{rank}\boldsymbol{A}$，$\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$ 是一个奇异值分解。对每个正奇异值 σ，把 $\boldsymbol{V}$、$\boldsymbol{U}$ 中满足 $\sigma_i = \sigma$ 的列分别排成 $\boldsymbol{V}_{\sigma}$、$\boldsymbol{U}_{\sigma}$；把 $\boldsymbol{V}$ 的后 $d-r$ 列与 $\boldsymbol{U}$ 的后 $m-r$ 列分别排成 $\boldsymbol{V}_0$、$\boldsymbol{U}_0$。则：

1. $\boldsymbol{V}_{\sigma}$ 与 $\boldsymbol{U}_{\sigma}$ 的列空间分别是 $\ker(\boldsymbol{A}^{\top}\boldsymbol{A} - \sigma^2\boldsymbol{I})$ 与 $\ker(\boldsymbol{A}\boldsymbol{A}^{\top} - \sigma^2\boldsymbol{I})$，且 $\boldsymbol{U}_{\sigma} = \boldsymbol{A}\boldsymbol{V}_{\sigma}/\sigma$；$\boldsymbol{V}_0$ 与 $\boldsymbol{U}_0$ 的列空间分别是 $\ker\boldsymbol{A}$ 与 $\operatorname{range}(\boldsymbol{A})^{\perp}$。

2. 若 $\boldsymbol{A} = \boldsymbol{U}'\boldsymbol{\Sigma}\boldsymbol{V}'^{\top}$ 是另一个奇异值分解，相应的分组记为 $\boldsymbol{V}'_\sigma$ 等，则对每个正奇异值 σ 存在正交矩阵 $\boldsymbol{R}_\sigma$，使

$$\boldsymbol{V}'_\sigma = \boldsymbol{V}_\sigma \boldsymbol{R}_\sigma, \qquad \boldsymbol{U}'_\sigma = \boldsymbol{U}_\sigma \boldsymbol{R}_\sigma.$$

3. 反过来，把 $\boldsymbol{V}_0$、$\boldsymbol{U}_0$ 分别换成 $\ker \boldsymbol{A}$ 与 $\operatorname{range}(\boldsymbol{A})^\perp$ 的任意标准正交基，或对某个 σ 同时右乘同一个正交矩阵 $\boldsymbol{R}_\sigma$，所得仍是奇异值分解。

特别地，每个正奇异值对应的项 $\sigma \boldsymbol{U}_\sigma \boldsymbol{V}_\sigma^{\top}$ 由 $\boldsymbol{A}$ 唯一确定。

证明 (1) 由 $\boldsymbol{A}\boldsymbol{V} = \boldsymbol{U}\boldsymbol{\Sigma}$ 与 $\boldsymbol{A}^{\top}\boldsymbol{U} = \boldsymbol{V}\boldsymbol{\Sigma}^{\top}$ 逐列读出：$\boldsymbol{A}\boldsymbol{v}_i = \sigma_i \boldsymbol{u}_i$，$\boldsymbol{A}^{\top}\boldsymbol{u}_i = \sigma_i \boldsymbol{v}_i$（$i \le \min(m,d)$），其余列被 $\boldsymbol{A}$ 或 $\boldsymbol{A}^{\top}$ 送到零。于是 $\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{v}_i = \sigma_i^2 \boldsymbol{v}_i$，$\boldsymbol{V}$ 的各列是 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 的一组标准正交特征基，特征值依次为 $\sigma_1^2, \dots$，不足 d 个时补零。由谱投影定理 4.23的第一条，特征空间 $\ker(\boldsymbol{A}^{\top}\boldsymbol{A} - \sigma^2 \boldsymbol{I})$ 恰由满足 $\sigma_i^2 = \sigma^2$ 的那些列张成，即 $\boldsymbol{V}_\sigma$ 的列空间。对 $\boldsymbol{A}\boldsymbol{A}^{\top} = \boldsymbol{U}(\boldsymbol{\Sigma}\boldsymbol{\Sigma}^{\top})\boldsymbol{U}^{\top}$ 同样讨论，得 $\boldsymbol{U}_\sigma$ 的列空间。由 $\boldsymbol{A}\boldsymbol{v}_i = \sigma \boldsymbol{u}_i$ 得 $\boldsymbol{U}_\sigma = \boldsymbol{A}\boldsymbol{V}_\sigma/\sigma$。

$\boldsymbol{V}_0$ 的 $d-r$ 列都满足 $\boldsymbol{A}\boldsymbol{v}_i = \boldsymbol{0}$，彼此标准正交，而 $\dim \ker \boldsymbol{A} = d-r$，所以它们是 $\ker \boldsymbol{A}$ 的基。$\boldsymbol{U}_0$ 的 $m-r$ 列与 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_r$ 正交，后者张成 $\operatorname{range}(\boldsymbol{A})$，而 $\dim \operatorname{range}(\boldsymbol{A})^\perp = m-r$，所以它们是 $\operatorname{range}(\boldsymbol{A})^\perp$ 的基。

(2) 由第一条，$\boldsymbol{V}_\sigma$ 与 $\boldsymbol{V}'_\sigma$ 的列是同一个子空间的两组标准正交基。与谱投影定理第四条的证明相同，$\boldsymbol{R}_\sigma = \boldsymbol{V}_\sigma^{\top}\boldsymbol{V}'_\sigma$ 是正交矩阵，且 $\boldsymbol{V}'_\sigma = \boldsymbol{V}_\sigma \boldsymbol{R}_\sigma$。再由第一条用于两个分解，

$$\boldsymbol{U}'_\sigma = \frac{1}{\sigma}\boldsymbol{A}\boldsymbol{V}'_\sigma = \frac{1}{\sigma}\boldsymbol{A}\boldsymbol{V}_\sigma \boldsymbol{R}_\sigma = \boldsymbol{U}_\sigma \boldsymbol{R}_\sigma.$$

(3) 分解按奇异值分组可以写成 $\boldsymbol{A} = \sum_{\sigma>0} \sigma \boldsymbol{U}_\sigma \boldsymbol{V}_\sigma^{\top}$，其中不出现 $\boldsymbol{V}_0$ 与 $\boldsymbol{U}_0$，所以替换它们不改变乘积。新的列仍与其余列正交：$\ker \boldsymbol{A}$ 是 $\operatorname{span}\{\boldsymbol{v}_1, \dots, \boldsymbol{v}_r\}$ 的正交补，$\operatorname{range}(\boldsymbol{A})^\perp$ 是 $\operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_r\}$ 的正交补，所以 $\boldsymbol{U}$、$\boldsymbol{V}$ 仍是正交矩阵。同时右乘 $\boldsymbol{R}_\sigma$ 时，$\boldsymbol{U}_\sigma \boldsymbol{R}_\sigma (\boldsymbol{V}_\sigma \boldsymbol{R}_\sigma)^{\top} = \boldsymbol{U}_\sigma \boldsymbol{V}_\sigma^{\top}$，乘积不变，列仍标准正交。最后一句由第二条得到：$\boldsymbol{U}'_\sigma \boldsymbol{V}'^{\top}_\sigma = \boldsymbol{U}_\sigma \boldsymbol{R}_\sigma \boldsymbol{R}_\sigma^{\top} \boldsymbol{V}_\sigma^{\top} = \boldsymbol{U}_\sigma \boldsymbol{V}_\sigma^{\top}$。 ∎

于是，奇异值和每个正奇异值对应的左、右奇异子空间都由 $\boldsymbol{A}$ 决定；同一个奇异值内部，左右两组基必须用同一个正交矩阵一起旋转，因为它们由 $\boldsymbol{u} = \boldsymbol{A}\boldsymbol{v}/\sigma$ 配对。零奇异值的两部分则彼此独立，可以分别任意选取。若正奇异值互不相同，每个 $\boldsymbol{R}_\sigma$ 都是 1×1 的正交矩阵 ± 1，奇异向量对只

差一个公共的符号。这与第 4.3.3节的情形相仿：具体的向量可以变，子空间和合并后的项不变。

5.3　奇异值与矩阵范数

第 1.3.3.2节与第 3.3.4节分别定义了 Frobenius 范数与谱范数，但没有给出谱范数的算法。奇异值分解把这个问题化为比较坐标的平方和。

为了统一书写，把零伸缩也计入。对 $\boldsymbol{x} \in \mathbb{R}^d$，写 $\boldsymbol{x} = \sum_{i=1}^{d} c_i \boldsymbol{v}_i$，其中 $c_i = \boldsymbol{v}_i^{\top}\boldsymbol{x}$，并约定 $i > \min(m,d)$ 时 $\sigma_i = 0$。于是对每个 $i \le d$ 都有 $\boldsymbol{A}\boldsymbol{v}_i = \sigma_i \boldsymbol{u}_i$ 或 $\boldsymbol{A}\boldsymbol{v}_i = \boldsymbol{0}$，后者对应 $\sigma_i = 0$。由 $\boldsymbol{u}_i$ 标准正交与 $\boldsymbol{v}_i$ 标准正交，

$$\|\boldsymbol{A}\boldsymbol{x}\|_2^2 = \sum_{i=1}^{d} \sigma_i^2 c_i^2, \qquad \|\boldsymbol{x}\|_2^2 = \sum_{i=1}^{d} c_i^2. \tag{5.4}$$

输出长度的平方是各 σ_i^2 以 c_i^2 为权的和。各 σ_i^2 都不超过最大的 σ_1^2，也不小于补零后最小的 σ_d^2，所以

$$\sigma_d \|\boldsymbol{x}\|_2 \le \|\boldsymbol{A}\boldsymbol{x}\|_2 \le \sigma_1 \|\boldsymbol{x}\|_2,$$

这里 $d > m$ 或 $\operatorname{rank}\boldsymbol{A} < d$ 时 $\sigma_d = 0$。取 $\boldsymbol{x} = \boldsymbol{v}_1$ 时只有 $c_1 = 1$，上界取等号；取 $\boldsymbol{x} = \boldsymbol{v}_d$ 时下界取等号。这一比较只用到坐标平方和，不涉及任何极值原理。

由上界及其可达性，单位输入的最大输出长度就是 σ_1。由迹的循环性，$\|\boldsymbol{A}\|_{\mathrm{F}}^2 = \operatorname{tr}(\boldsymbol{A}^{\top}\boldsymbol{A}) = \operatorname{tr}\big(\boldsymbol{V}(\boldsymbol{\Sigma}^{\top}\boldsymbol{\Sigma})\boldsymbol{V}^{\top}\big) = \operatorname{tr}(\boldsymbol{\Sigma}^{\top}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}\boldsymbol{V}) = \sum_i \sigma_i^2$。因此

$$\|\boldsymbol{A}\|_2 = \sigma_1, \tag{5.5}$$

$$\|\boldsymbol{A}\|_{\mathrm{F}} = \Big(\sum_{i=1}^{r} \sigma_i^2\Big)^{1/2}. \tag{5.6}$$

正奇异值的个数等于 $\operatorname{rank}\boldsymbol{A}$，这已在构造中证明。谱范数只看最强的一个伸缩，Frobenius 范数把全部伸缩的平方加在一起，所以 $\|\boldsymbol{A}\|_2 \le \|\boldsymbol{A}\|_{\mathrm{F}} \le \sqrt{r}\,\|\boldsymbol{A}\|_2$。

下界在秩亏时为零，并不提供信息。$\ker\boldsymbol{A}$ 中的非零输入被送到零，它们的输出长度不说明 $\boldsymbol{A}$ 在其他方向上作用多弱。有意义的问题是在 $\ker\boldsymbol{A}$ 的正交补 $\operatorname{span}\{\boldsymbol{v}_1,\dots,\boldsymbol{v}_r\}$ 上，单位输入至少被送出多远。满列秩时 $\ker\boldsymbol{A} = \{\boldsymbol{0}\}$，这个正交补就是整个输入空间。可逆方阵的逆矩阵则把每个伸缩倍数倒过来，最弱的放大变成逆矩阵最强的放大。下面的定理汇总这几项读数。

定理 5.4 最小奇异值与逆矩阵的范数 设 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$ 的秩为 $r \geq 1$，奇异值分解如定理 5.1所示。

1. 对 $\ker \boldsymbol{A}$ 的正交补中的任意 $\boldsymbol{x}$，$\|\boldsymbol{A}\boldsymbol{x}\|_2 \geq \sigma_r \|\boldsymbol{x}\|_2$，等号在 $\boldsymbol{x} = \boldsymbol{v}_r$ 时成立。
2. 若 $\boldsymbol{A}$ 满列秩，即 $r = d \leq m$，则对所有 $\boldsymbol{x} \in \mathbb{R}^d$，$\|\boldsymbol{A}\boldsymbol{x}\|_2 \geq \sigma_d \|\boldsymbol{x}\|_2$，且
$$\min_{\|\boldsymbol{x}\|_2=1} \|\boldsymbol{A}\boldsymbol{x}\|_2 = \sigma_d > 0.$$
3. 若 $\boldsymbol{A}$ 是可逆方阵（$m = d = r$），则 $\boldsymbol{A}^{-1} = \sum_{i=1}^{d} \sigma_i^{-1} \boldsymbol{v}_i \boldsymbol{u}_i^{\top}$，并且
$$\|\boldsymbol{A}^{-1}\|_2 = \frac{1}{\sigma_d}. \tag{5.7}$$

证明 由构造，$\ker \boldsymbol{A}$ 由 $\boldsymbol{v}_{r+1}, \ldots, \boldsymbol{v}_d$ 张成，其正交补由 $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_r$ 张成。对其中的 $\boldsymbol{x} = \sum_{i\leq r} c_i \boldsymbol{v}_i$，由式 (5.4)，

$$\|\boldsymbol{A}\boldsymbol{x}\|_2^2 = \sum_{i\leq r} \sigma_i^2 c_i^2 \geq \sigma_r^2 \sum_{i\leq r} c_i^2 = \sigma_r^2 \|\boldsymbol{x}\|_2^2,$$

其中用到 $\sigma_i \geq \sigma_r$（$i \leq r$）；取 $\boldsymbol{x} = \boldsymbol{v}_r$ 时只有 $c_r = 1$，等号成立。这是第一条。满列秩时正交补就是 $\mathbb{R}^d$，且 $\sigma_r = \sigma_d > 0$，第一条即给出第二条。

对第三条，令 $\boldsymbol{B} = \sum_i \sigma_i^{-1} \boldsymbol{v}_i \boldsymbol{u}_i^{\top}$。由 $\boldsymbol{v}_i^{\top} \boldsymbol{v}_j = \delta_{i,j}$，

$$\boldsymbol{A}\boldsymbol{B} = \sum_{i,j} \sigma_i \sigma_j^{-1} \boldsymbol{u}_i (\boldsymbol{v}_i^{\top} \boldsymbol{v}_j) \boldsymbol{u}_j^{\top} = \sum_i \boldsymbol{u}_i \boldsymbol{u}_i^{\top} = \boldsymbol{U}\boldsymbol{U}^{\top} = \boldsymbol{I},$$

方阵的右逆就是逆，所以 $\boldsymbol{B} = \boldsymbol{A}^{-1}$。这个和式本身就是 $\boldsymbol{A}^{-1}$ 的奇异值分解：右奇异向量为 $\boldsymbol{u}_i$，左奇异向量为 $\boldsymbol{v}_i$，奇异值为 σ_i^{-1}，其中最大的是 σ_d^{-1}。由式 (5.5)，$\|\boldsymbol{A}^{-1}\|_2 = 1/\sigma_d$。 ■

满列秩只保证最小放大倍数为正，并不保证它不太小。式 (5.7)说明，最小奇异值越小，逆矩阵把输出端的误差放大得越厉害。最大奇异值衡量最强的放大，最小奇异值衡量最弱的放大，二者之比就是第 7.1.3节的矩阵条件数，它决定线性方程的解对数据误差有多敏感。

当 $r < d$ 时（$m < d$ 时总是如此），存在非零输入被送到零，单位输入的最小输出长度为零，这时只能在零空间的正交补上谈最弱的放大。最弱放大的方向 $\boldsymbol{v}_d$ 也有直接用处：第 9.6节的齐次最小二乘在单位向量中最小化 $\|\boldsymbol{A}\boldsymbol{x}\|_2$，由上面的下界及其取等条件，最优解就是 $\boldsymbol{v}_d$。

本节的上下界是对单个输入的比较。若要在所有 k 维子空间中挑出保留输出能量最多的一个，就需要比较子空间，这是第 15章用 Rayleigh 商和迹极值处理的最优选择问题。

5.4 分解的核验与几何解释

一组因子是否确实构成奇异值分解，可以只用矩阵乘法检查。本节先给出检查项目和一个完整的算例，再用单位球的像解释三个因子的作用，最后说明数值计算中这些检查为什么要分开报告。

因子的核验　给定 $\boldsymbol{U}$、$\boldsymbol{\Sigma}$、$\boldsymbol{V}$，需要检查三件事：$\boldsymbol{U}^{\top}\boldsymbol{U}=\boldsymbol{I}$ 与 $\boldsymbol{V}^{\top}\boldsymbol{V}=\boldsymbol{I}$；$\boldsymbol{\Sigma}$ 只有非负的对角元，并按降序排列；$\boldsymbol{A}\boldsymbol{V}=\boldsymbol{U}\boldsymbol{\Sigma}$，逐列看就是 $\boldsymbol{A}\boldsymbol{v}_i=\sigma_i\boldsymbol{u}_i$。三项都成立时，在 $\boldsymbol{A}\boldsymbol{V}=\boldsymbol{U}\boldsymbol{\Sigma}$ 两边右乘 $\boldsymbol{V}^{\top}$，由 $\boldsymbol{V}\boldsymbol{V}^{\top}=\boldsymbol{I}$ 即得 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$。

正交性不能省略。若只核对乘积，任何分解 $\boldsymbol{A}=\boldsymbol{B}\boldsymbol{C}$ 都可以写成 $\boldsymbol{U}=\boldsymbol{B}$、$\boldsymbol{\Sigma}=\boldsymbol{I}$、$\boldsymbol{V}^{\top}=\boldsymbol{C}$ 的形式，却与奇异值毫无关系。另一方面，$\boldsymbol{A}^{\top}\boldsymbol{U}=\boldsymbol{V}\boldsymbol{\Sigma}^{\top}$ 由前三项推出，可以作为附加检查，它同时检验左奇异向量是否是 $\boldsymbol{A}\boldsymbol{A}^{\top}$ 的特征向量。

示例 5.5　二阶矩阵的奇异值分解与核验　取一个不对称的二阶矩阵

$$\boldsymbol{A}=\begin{bmatrix}3 & 0\\ 4 & 5\end{bmatrix},$$

沿第 5.2节的构造求出它的奇异值分解，再按上面的三项逐一核验。

构造从对称矩阵

$$\boldsymbol{A}^{\top}\boldsymbol{A}=\begin{bmatrix}25 & 20\\ 20 & 25\end{bmatrix}$$

出发。它的特征多项式为 $(z-25)^2-400=(z-45)(z-5)$，特征值为 45 与 5，对应的单位特征向量为 $\boldsymbol{v}_1=(1,1)^{\top}/\sqrt{2}$ 与 $\boldsymbol{v}_2=(1,-1)^{\top}/\sqrt{2}$。它们就是右奇异向量；特征值开方得到奇异值 $\sigma_1=\sqrt{45}=3\sqrt{5}$，$\sigma_2=\sqrt{5}$。输出端的方向不必另解方程，由 $\boldsymbol{u}_i=\boldsymbol{A}\boldsymbol{v}_i/\sigma_i$ 直接得到：

$$\boldsymbol{u}_1=\frac{1}{3\sqrt{5}}\cdot\frac{1}{\sqrt{2}}\begin{bmatrix}3\\ 9\end{bmatrix}=\frac{1}{\sqrt{10}}\begin{bmatrix}1\\ 3\end{bmatrix},\qquad \boldsymbol{u}_2=\frac{1}{\sqrt{5}}\cdot\frac{1}{\sqrt{2}}\begin{bmatrix}3\\ -1\end{bmatrix}=\frac{1}{\sqrt{10}}\begin{bmatrix}3\\ -1\end{bmatrix}.$$

接着逐项核验。正交性：$\boldsymbol{u}_1^{\top}\boldsymbol{u}_2 = (3-3)/10 = 0$，两者长度为 1，$\boldsymbol{v}_1, \boldsymbol{v}_2$ 同样标准正交。对角元：$\sigma_1 \geq \sigma_2 > 0$，非负且降序。乘积：按秩一和式重建，

$$\sigma_1 \boldsymbol{u}_1 \boldsymbol{v}_1^{\top} + \sigma_2 \boldsymbol{u}_2 \boldsymbol{v}_2^{\top} = \frac{3}{2}\begin{bmatrix} 1 & 1 \\ 3 & 3 \end{bmatrix} + \frac{1}{2}\begin{bmatrix} 3 & -3 \\ -1 & 1 \end{bmatrix} = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix} = \boldsymbol{A},$$

其中 $\sigma_1/\sqrt{20} = 3/2$，$\sigma_2/\sqrt{20} = 1/2$。作为附加检查，$\boldsymbol{A}^{\top}\boldsymbol{u}_1 = (15, 15)^{\top}/\sqrt{10} = 3\sqrt{5}\,\boldsymbol{v}_1$，与式 (5.3)相符。

有了分解，上一节的几项大小就能直接读出：$\|\boldsymbol{A}\|_2 = 3\sqrt{5} \approx 6.71$；$\|\boldsymbol{A}\|_{\mathrm{F}}^2 = 45 + 5 = 50$，与逐元素平方和 $9 + 16 + 25$ 一致；两个奇异值都为正，$\boldsymbol{A}$ 可逆，且 $\|\boldsymbol{A}^{-1}\|_2 = 1/\sqrt{5}$。

这个矩阵不对称，它的特征值是对角元 3 与 5，与奇异值 6.71、2.24 都不同。特征值描述沿特征方向的倍数，奇异值描述把输入方向送到另一组正交方向时的倍数。对称半正定矩阵的奇异值就是它的特征值（第 5.1节），一般矩阵二者不同。

单位球的像　几何上，SVD 把 $\boldsymbol{A}$ 的作用拆成三步：$\boldsymbol{V}^{\top}$ 把输入写成右奇异方向上的坐标，$\boldsymbol{\Sigma}$ 把第 i 个坐标乘以 σ_i，$\boldsymbol{U}$ 再把结果放到输出空间的左奇异方向上。正交矩阵保持长度，所以只有中间一步改变长度。于是 $\boldsymbol{A}$ 把输入端的单位球映成输出空间中一个椭球；秩亏时这个椭球落在低维子空间内。

具体地，单位球中的 $\boldsymbol{x} = \sum_i c_i \boldsymbol{v}_i$ 满足 $\sum_i c_i^2 \leq 1$，其像为 $\boldsymbol{y} = \sum_{i \leq r} \sigma_i c_i \boldsymbol{u}_i$，它落在 $\operatorname{span}\{\boldsymbol{u}_1, \ldots, \boldsymbol{u}_r\}$ 中，坐标 $y_i = \boldsymbol{u}_i^{\top}\boldsymbol{y} = \sigma_i c_i$ 满足 $\sum_{i \leq r} (y_i/\sigma_i)^2 = \sum_{i \leq r} c_i^2 \leq 1$。反过来，该子空间中满足这一不等式的 $\boldsymbol{y}$ 是 $\boldsymbol{x} = \sum_{i \leq r} (y_i/\sigma_i)\boldsymbol{v}_i$ 的像，而这个 $\boldsymbol{x}$ 在单位球中。所以像恰为

$$\Big\{ \boldsymbol{y} \in \operatorname{span}\{\boldsymbol{u}_1, \ldots, \boldsymbol{u}_r\} : \sum_{i=1}^{r} \frac{(\boldsymbol{u}_i^{\top}\boldsymbol{y})^2}{\sigma_i^2} \leq 1 \Big\},$$

即以 $\sigma_i \boldsymbol{u}_i$ 为半轴的椭球：$\boldsymbol{v}_i$ 方向的单位向量被送到半轴端点 $\sigma_i \boldsymbol{u}_i$。

若 $r < d$，单位球面上的点也可能映到这个椭球的内部，例如 $(\boldsymbol{v}_1 + \boldsymbol{v}_d)/\sqrt{2}$ 被送到 $\sigma_1 \boldsymbol{u}_1/\sqrt{2}$，所以这里用单位球而不是球面描述整个像。按这一图像，最长半轴就是最强的放大 $\|\boldsymbol{A}\|_2$，各半轴长度的平方和就是 $\|\boldsymbol{A}\|_{\mathrm{F}}^2$。图 5.2用二维旋转矩阵 $\boldsymbol{R}(\theta) = \left[\begin{smallmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{smallmatrix}\right]$ 构造了一个输入方向与输出方向不同的例子。

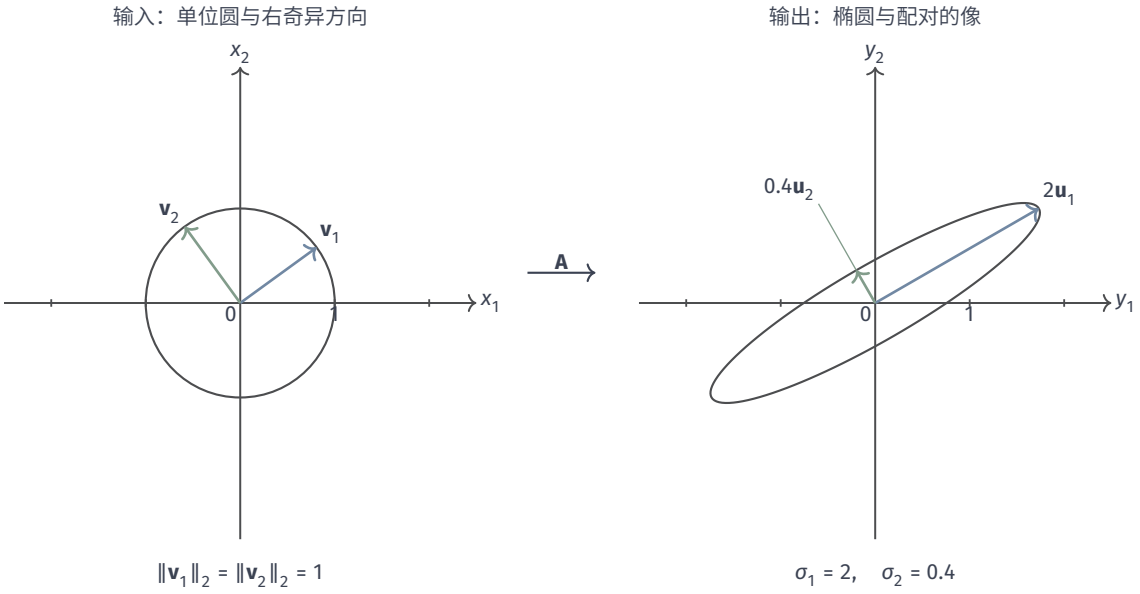


图 5.2 矩阵 $\boldsymbol{A} = \boldsymbol{R}(\pi/6)\,\mathrm{diag}(2, 0.4)\boldsymbol{R}(\pi/5)^{\mathsf{T}}$ 将单位圆变为椭圆。蓝、绿分别对应两个奇异方向；同色箭头在左侧标出 $\boldsymbol{v}_i$，在右侧标出其像 $\sigma_i\boldsymbol{u}_i$。两侧坐标比例相同。奇异值决定长度变化，左右方向可以不同，因而这不是沿特征方向的同空间缩放。图为教学构造。

数值计算中的核验 上面的构造与核验都是精确的代数运算。数值软件返回的因子 $\hat{\boldsymbol{U}}$、$\hat{\boldsymbol{\Sigma}}$、$\hat{\boldsymbol{V}}$ 带有舍入误差，各项等式只能近似成立，所以要分别报告两类残差：重建误差 $\|\boldsymbol{A} - \hat{\boldsymbol{U}}\hat{\boldsymbol{\Sigma}}\hat{\boldsymbol{V}}^{\mathsf{T}}\|/\|\boldsymbol{A}\|$，以及正交性误差 $\|\hat{\boldsymbol{U}}^{\mathsf{T}}\hat{\boldsymbol{U}} - \boldsymbol{I}\|$ 与 $\|\hat{\boldsymbol{V}}^{\mathsf{T}}\hat{\boldsymbol{V}} - \boldsymbol{I}\|$。

两类残差不能互相代替。前面的例子已经说明，重建误差为零并不保证因子正交；反过来，两组列都正交、乘积却不等于 $\boldsymbol{A}$，也只说明找到了某种正交矩阵。只有两类残差都小，才能把 $\hat{\boldsymbol{\Sigma}}$ 的对角元当作 $\boldsymbol{A}$ 的奇异值的近似值；它们离真实奇异值有多远，由第 7章的奇异值扰动界判断。

构造路线从 $\boldsymbol{A}^{\mathsf{T}}\boldsymbol{A}$ 出发，这条路线适合证明存在性，却不宜照搬到数值计算中。$\boldsymbol{A}^{\mathsf{T}}\boldsymbol{A}$ 的特征值是 σ_i^2，最大与最小奇异值之比在其中变成平方，小奇异值相对于大奇异值变得更小，容易被舍入误差淹没。第 14.1.3节以最小二乘的正规方程为例分析这种平方带来的误差风险。实际计算奇异值分解的算法直接作用于 $\boldsymbol{A}$ 本身，其构造与误差分析不在本书展开。

5.5 本章小结

本章开头问：输入、输出各取一组标准正交基时，是否任何矩阵都能化为对角形？答案是肯定的。由 $\boldsymbol{A}^{\mathsf{T}}\boldsymbol{A}$ 的谱分解取右奇异向量 $\boldsymbol{v}_i$，开方得到奇异值 σ_i，再令 $\boldsymbol{u}_i = \boldsymbol{A}\boldsymbol{v}_i/\sigma_i$ 并补全，就得到 $\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathsf{T}}$，即 $\boldsymbol{A}\boldsymbol{v}_i = \sigma_i\boldsymbol{u}_i$。这一构造只依赖谱定理，对矩形矩阵、不能对角化的方阵和非正规方阵都成立。

分解有完整、薄与秩分解三种写法，区别只在是否保留零伸缩的方向。奇异值由 $\boldsymbol{A}$ 唯一确定，是 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 特征值的非负平方根；每个正奇异值的左、右奇异子空间也唯一，同一奇异值内部的两组基只能用同一个正交矩阵一起旋转。零奇异值对应的 $\ker \boldsymbol{A}$ 与 $\operatorname{range}(\boldsymbol{A})^{\perp}$ 的基则可以各自任意选取。

在奇异坐标中，输出长度的平方是 $\sum_i \sigma_i^2 c_i^2$。由此直接读出 $\|\boldsymbol{A}\|_2 = \sigma_1$、$\|\boldsymbol{A}\|_{\mathrm{F}}^2 = \sum_i \sigma_i^2$、$\operatorname{rank} \boldsymbol{A}$ 等于正奇异值的个数；在零空间的正交补上最弱的放大是 σ_r，可逆方阵的 $\|\boldsymbol{A}^{-1}\|_2 = 1/\sigma_d$。几何上，$\boldsymbol{A}$ 把单位球映成以 $\sigma_i \boldsymbol{u}_i$ 为半轴的椭球。

核验一组因子要同时检查正交性与 $\boldsymbol{A}\boldsymbol{V} = \boldsymbol{U}\boldsymbol{\Sigma}$；数值计算中重建误差和正交性误差须分别报告，并且不宜通过显式形成 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 来计算。

这些读数将在后面几章使用。第 6章由奇异值分解把矩阵分成伸缩与保长两部分，第 7章用 $\sigma_{\max}/\sigma_{\min}$ 度量误差放大，并估计奇异值本身受扰动时的变化。按奇异值从大到小保留方向、得到最佳低秩近似，是第 15章的任务。

第 6 章

极分解

非零复数 z 可以写成 $z = e^{i\theta} r$：先乘正数 r 改变长度，再乘单位复数 $e^{i\theta}$ 转动方向。本章对矩阵提出同样的问题：给定 $\boldsymbol{A}$，能否把它写成 $\boldsymbol{A} = \boldsymbol{W}\boldsymbol{H}$，使 $\boldsymbol{H}$ 沿一组互相垂直的方向作非负伸缩，$\boldsymbol{W}$ 保持长度？这样的分解是否唯一？先转向、后伸缩是否也可以？矩阵奇异或不是方阵时，又能保留多少？

第 5章的奇异值分解已经把 $\boldsymbol{A}$ 写成“转向、伸缩、再转向”的三段。本章把三段重新组合成两段，并关心另一个问题：两个因子能否直接由 $\boldsymbol{A}$ 求出，而不先求出全部奇异向量。

第 6.1节先处理可逆方阵：利用正交因子保持长度，消去它，得到只含伸缩因子的开方方程。第 6.2节沿谱开方，构造唯一的正定伸缩因子。第 6.3节撤销伸缩求出正交因子，并比较先伸缩后转向与先转向后伸缩两种写法。第 6.4节借助奇异值分解处理奇异方阵与矩形矩阵，说明核怎样使正交因子失去唯一性。第 6.5节把开方和求逆中共同使用的“沿谱改写特征值”归纳为对称矩阵的函数。

本章用到第 4章的谱定理、谱投影与定号性判据，奇异情形还用到第 5章的奇异值分解。极分解的正交因子还有一个最优性：第 15章将证明，在 Frobenius 范数下它是离 $\boldsymbol{A}$ 最近的正交矩阵（定理 15.21）。这需要比较全部正交矩阵，属于约束下的矩阵逼近问题，本章不展开。

6.1 伸缩与正交转向的分离

先看一个具体矩阵。取

$$\boldsymbol{A} = \begin{bmatrix} 0 & -1 \\ 3 & 0 \end{bmatrix},$$

它把 $\boldsymbol{e}_1$ 送到 $3\boldsymbol{e}_2$，把 $\boldsymbol{e}_2$ 送到 $-\boldsymbol{e}_1$。这个作用既改变长度，又改变方向：$\boldsymbol{e}_1$ 被拉长为原来的 3 倍，同时两个坐标轴都被转了 90 度。我们希望把它拆成两步：先由对称正定的 $\boldsymbol{H}$ 沿一组正交方向伸缩，再由正交矩阵 $\boldsymbol{W}$ 保长地改变方向，即求 $\boldsymbol{A} = \boldsymbol{W}\boldsymbol{H}$。

本节和后两节先假定 $\boldsymbol{A} \in \mathbb{R}^{d\times d}$ 可逆。这时 $\boldsymbol{A}$ 不把任何非零向量压成零，伸缩可以撤销，所求的 $\boldsymbol{H}$ 应当正定。正交矩阵既可以是旋转，也可以包含反射，这里不加限制；$\boldsymbol{A}$ 奇异或不是方阵的情形在第 6.4节处理。

两个因子同时未知，先设法消去一个。若 $\boldsymbol{A} = \boldsymbol{W}\boldsymbol{H}$，其中 $\boldsymbol{W}^{\top}\boldsymbol{W} = \boldsymbol{I}$、$\boldsymbol{H}^{\top} = \boldsymbol{H}$，则把等式两边分别转置后与原式相乘，得到

$$\boldsymbol{A}^{\top}\boldsymbol{A} = \boldsymbol{H}^{\top}\boldsymbol{W}^{\top}\boldsymbol{W}\boldsymbol{H} = \boldsymbol{H}^{2}. \tag{6.1}$$

正交因子在相乘时消失了，因为它保持长度：$\|\boldsymbol{A}\boldsymbol{x}\|_2 = \|\boldsymbol{W}\boldsymbol{H}\boldsymbol{x}\|_2 = \|\boldsymbol{H}\boldsymbol{x}\|_2$。

记 $\boldsymbol{S} = \boldsymbol{A}^{\top}\boldsymbol{A}$，它完全由已知的 $\boldsymbol{A}$ 确定。于是原问题的前一半化为一个开方问题：找一个对称正定矩阵 $\boldsymbol{H}$，使 $\boldsymbol{H}^2 = \boldsymbol{S}$。需要注意，式 (6.1)只是分解若存在就必须满足的条件；这样的 $\boldsymbol{H}$ 是否存在、由它能否再得到正交的 $\boldsymbol{W}$，都还没有证明。

开方之前先确认 $\boldsymbol{S}$ 的结构。它对称，因为 $(\boldsymbol{A}^{\top}\boldsymbol{A})^{\top} = \boldsymbol{A}^{\top}\boldsymbol{A}$；对任意非零 $\boldsymbol{x}$，

$$\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x} = (\boldsymbol{A}\boldsymbol{x})^{\top}(\boldsymbol{A}\boldsymbol{x}) = \|\boldsymbol{A}\boldsymbol{x}\|_2^2 > 0,$$

最后一步用到 $\boldsymbol{A}$ 可逆，从而 $\boldsymbol{A}\boldsymbol{x} \neq \boldsymbol{0}$。所以 $\boldsymbol{S}$ 对称正定，可以使用第 4.3节的正交谱分解，且全部特征值为正。

在贯穿例中，

$$\boldsymbol{S} = \boldsymbol{A}^{\top}\boldsymbol{A} = \begin{bmatrix} 0 & 3 \\ -1 & 0 \end{bmatrix}\begin{bmatrix} 0 & -1 \\ 3 & 0 \end{bmatrix} = \begin{bmatrix} 9 & 0 \\ 0 & 1 \end{bmatrix}.$$

这里 $\boldsymbol{S}$ 恰好是对角矩阵，最直接的做法是沿两个坐标轴分别取正平方根，得到候选 $\boldsymbol{H} = \operatorname{diag}(3,1)$。一般的 $\boldsymbol{S}$ 不是对角矩阵，下一节用谱分解把它化到这种情形。

6.2 伸缩因子的构造

对上一节的 $\boldsymbol{S} = \boldsymbol{A}^{\top}\boldsymbol{A}$ 作正交谱分解 $\boldsymbol{S} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\top}$，其中 $\boldsymbol{Q} = [\boldsymbol{q}_1, \dots, \boldsymbol{q}_d]$ 正交，$\boldsymbol{\Lambda} = \operatorname{diag}(\lambda_1, \dots, \lambda_d)$，全部 $\lambda_i > 0$。在特征方向 $\boldsymbol{q}_i$ 上，$\boldsymbol{S}$ 只作标量伸缩 λ_i 倍。既然希望 $\boldsymbol{H}$ 作用两次等于 $\boldsymbol{S}$，自然尝试让 $\boldsymbol{H}$ 沿同一方向伸缩 $\sqrt{\lambda_i}$ 倍，即构造

$$\boldsymbol{H} = \boldsymbol{Q}\operatorname{diag}\big(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_d}\big)\boldsymbol{Q}^{\top}. \tag{6.2}$$

这是我们主动选取的一个候选，并没有预先假定未知的 $\boldsymbol{H}$ 必须与 $\boldsymbol{S}$ 共用特征基；它是否满足要求，要靠验证。

验证只需矩阵乘法。记 $\boldsymbol{\Lambda}^{1/2} = \operatorname{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_d})$，由 $\boldsymbol{Q}^{\top}\boldsymbol{Q} = \boldsymbol{I}$，

$$\boldsymbol{H}^2 = \boldsymbol{Q}\boldsymbol{\Lambda}^{1/2}(\boldsymbol{Q}^{\top}\boldsymbol{Q})\boldsymbol{\Lambda}^{1/2}\boldsymbol{Q}^{\top} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\top} = \boldsymbol{S}.$$

又 $\boldsymbol{H}^{\top} = \boldsymbol{Q}(\boldsymbol{\Lambda}^{1/2})^{\top}\boldsymbol{Q}^{\top} = \boldsymbol{H}$，而式 (6.2)本身就是 $\boldsymbol{H}$ 的正交谱分解，特征值 $\sqrt{\lambda_i}$ 全为正，所以 $\boldsymbol{H}$ 对称正定。所需的伸缩因子已经求出，记作 $\boldsymbol{S}^{1/2}$，称为 $\boldsymbol{S}$ 的正定平方根，也称**矩阵平方根**（matrix square root）。

构造本身只用到 $\lambda_i \geq 0$，所以对半正定的 $\boldsymbol{S}$ 同样可行，此时得到半正定的 $\boldsymbol{H}$。还剩一个问题：$\boldsymbol{Q}$ 不唯一，特征值有重根时，重根空间内可以换用别的标准正交基。

方程 $\boldsymbol{X}^2 = \boldsymbol{S}$ 本身也可能有许多解。例如 $\boldsymbol{I}$、$-\boldsymbol{I}$ 与 $\operatorname{diag}(1,-1)$ 的平方都是 $\boldsymbol{I}_2$，后两个对称却不半正定；不对称的 $\left[\begin{smallmatrix}0&1\\0&0\end{smallmatrix}\right]$ 与零矩阵的平方都是零矩阵。所以“平方等于 $\boldsymbol{S}$”这一代数条件不足以确定伸缩因子。下面的定理说明，只要要求解对称半正定，答案就唯一，因而与 $\boldsymbol{Q}$ 的选取无关。

定理 6.1　半正定平方根的存在与唯一　设 $\boldsymbol{S} \in \mathbb{R}^{d\times d}$ 对称半正定，有正交谱分解 $\boldsymbol{S} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\top}$。则存在唯一的对称半正定矩阵 $\boldsymbol{X}$ 满足 $\boldsymbol{X}^2 = \boldsymbol{S}$，它就是式 (6.2)给出的 $\boldsymbol{S}^{1/2}$。$\boldsymbol{S}$ 正定时，$\boldsymbol{S}^{1/2}$ 也正定。

证明　存在性与正定性已由上面的验证给出：$\boldsymbol{S}$ 半正定时全部 $\lambda_i \geq 0$，$\sqrt{\lambda_i}$ 有定义，式 (6.2)是对称半正定矩阵且平方为 $\boldsymbol{S}$；$\boldsymbol{S}$ 正定时全部 $\sqrt{\lambda_i} > 0$。

下证唯一性。设 $\boldsymbol{X}$ 对称半正定且 $\boldsymbol{X}^2 = \boldsymbol{S}$。对 $\boldsymbol{X}$ 本身作正交谱分解 $\boldsymbol{X} = \sum_{j=1}^{d} \mu_j \boldsymbol{p}_j \boldsymbol{p}_j^{\top}$，其中 $\boldsymbol{p}_1, \dots, \boldsymbol{p}_d$ 是标准正交基，$\mu_j \geq 0$。由 $\boldsymbol{p}_j^{\top}\boldsymbol{p}_k = \delta_{j,k}$，

$$\boldsymbol{S} = \boldsymbol{X}^2 = \sum_{j=1}^{d} \mu_j^2 \boldsymbol{p}_j \boldsymbol{p}_j^{\top},$$

所以 $\boldsymbol{S}\boldsymbol{p}_j = \mu_j^2 \boldsymbol{p}_j$，每个 $\boldsymbol{p}_j$ 都是 $\boldsymbol{S}$ 的特征向量。

取 $\boldsymbol{S}$ 的任一特征值 λ，考察特征空间 $\ker(\boldsymbol{S} - \lambda\boldsymbol{I})$。把任意 $\boldsymbol{x}$ 展开为 $\boldsymbol{x} = \sum_j c_j \boldsymbol{p}_j$，则

$$(\boldsymbol{S} - \lambda\boldsymbol{I})\boldsymbol{x} = \sum_{j=1}^{d} c_j(\mu_j^2 - \lambda)\boldsymbol{p}_j,$$

由 $\boldsymbol{p}_j$ 线性无关，它为零当且仅当凡 $\mu_j^2 \neq \lambda$ 的 j 都有 $c_j = 0$。因此 $\ker(\boldsymbol{S} - \lambda\boldsymbol{I})$ 恰由满足 $\mu_j^2 = \lambda$ 的那些 $\boldsymbol{p}_j$ 张成。对这些 j，$\mu_j \geq 0$ 迫使 $\mu_j = \sqrt{\lambda}$，于是对特征空间中的每个 $\boldsymbol{x}$，

$$\boldsymbol{X}\boldsymbol{x} = \sum_{\mu_j^2 = \lambda} c_j \mu_j \boldsymbol{p}_j = \sqrt{\lambda}\,\boldsymbol{x}.$$

另一方面，由式 (6.2)，$\boldsymbol{S}^{1/2}\boldsymbol{q}_i = \sqrt{\lambda_i}\boldsymbol{q}_i$，而 $\ker(\boldsymbol{S}-\lambda\boldsymbol{I})$ 由满足 $\lambda_i = \lambda$ 的 $\boldsymbol{q}_i$ 张成，所以 $\boldsymbol{S}^{1/2}$ 在这个特征空间上同样是乘以 $\sqrt{\lambda}$。

这样，$\boldsymbol{X}$ 与 $\boldsymbol{S}^{1/2}$ 在 $\boldsymbol{S}$ 的每个特征空间上作用相同。由谱定理，这些特征空间合起来张成 $\mathbb{R}^d$（各 $\boldsymbol{q}_i$ 都落在其中某一个里），线性映射在一组基上相同即处处相同，故 $\boldsymbol{X} = \boldsymbol{S}^{1/2}$。 ■

唯一性的论证直接说明了两件事。第一，在重根空间内换基，相应的 $\boldsymbol{q}_i$ 变了，但特征空间和其上的作用“乘以 $\sqrt{\lambda}$”不变，所以 $\boldsymbol{S}^{1/2}$ 不依赖 $\boldsymbol{Q}$ 的选取。第二，唯一性只针对半正定解；去掉这一要求，$\boldsymbol{X}^2 = \boldsymbol{S}$ 一般有许多解，$-\boldsymbol{S}^{1/2}$ 就是其中之一。

在贯穿例中，$\boldsymbol{S} = \operatorname{diag}(9,1)$，可取 $\boldsymbol{Q} = \boldsymbol{I}$，得到 $\boldsymbol{H} = \operatorname{diag}(3,1)$，直接核对 $\boldsymbol{H}^2 = \operatorname{diag}(9,1) = \boldsymbol{S}$。上一节凭直觉写出的候选正是唯一的正定平方根。到这里，解题进度是：已经得到伸缩因子 $\boldsymbol{H}$，还需要求出 $\boldsymbol{W}$ 并验证它正交。

这里所做的“把每个特征值换成它的平方根”，将在第 6.5节成为矩阵函数的一个具体例子；但构造和验证本身只用到谱分解、标量开方与矩阵乘法。

所得的平方根带来一个后文直接使用的长度恒等式。由 $\boldsymbol{S}^{1/2}$ 对称及 $(\boldsymbol{S}^{1/2})^2 = \boldsymbol{S}$，对半正定 $\boldsymbol{S}$ 与任意 $\boldsymbol{x}$，

$$\|\boldsymbol{S}^{1/2}\boldsymbol{x}\|_2^2 = \boldsymbol{x}^{\top}\boldsymbol{S}^{1/2}\boldsymbol{S}^{1/2}\boldsymbol{x} = \boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}. \tag{6.3}$$

它把第 3.4.2.1节以 $\boldsymbol{S}$ 加权的长度化为普通欧氏长度。对 $\boldsymbol{S} = \boldsymbol{A}^{\top}\boldsymbol{A}$，它给出 $\|\boldsymbol{H}\boldsymbol{x}\|_2 = \|\boldsymbol{A}\boldsymbol{x}\|_2$，说明 $\boldsymbol{H}$ 承担了 $\boldsymbol{A}$ 的全部长度变化；但这并不表示 $\boldsymbol{H}\boldsymbol{x}$ 与 $\boldsymbol{A}\boldsymbol{x}$ 方向相同，方向的差别正要由 $\boldsymbol{W}$ 补上。第 11章分析 Gauss–Seidel 迭代的收缩时，就用式 (6.3)把能量范数写成欧氏长度。

若只需表示同一个长度，平方根并不是唯一的选择。由定理 3.52，正定 $\boldsymbol{S}$ 还可写成 $\boldsymbol{S} = \boldsymbol{L}^{\top}\boldsymbol{L}$，$\boldsymbol{L}$ 可逆，此时同样有 $\|\boldsymbol{L}\boldsymbol{x}\|_2^2 = \boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x} = \|\boldsymbol{S}^{1/2}\boldsymbol{x}\|_2^2$。不过这只说明两个向量 $\boldsymbol{L}\boldsymbol{x}$ 与 $\boldsymbol{S}^{1/2}\boldsymbol{x}$ 长度相同，并不表示两个矩阵对向量的作用相同：$\boldsymbol{L}$ 一般不对称，$\boldsymbol{S}^{1/2}$ 则由定理 6.1唯一确定。

下一节会看到，二者恰好相差一个正交因子。第 10章的 Cholesky 分解把 $\boldsymbol{L}$ 取成三角矩阵，那时作用 $\boldsymbol{L}^{-1}$ 只需解三角方程，不必求出完整的谱分解。

6.3 正交因子与左右极分解

伸缩因子求出以后，正交因子由撤销伸缩得到。本节先完成 $\boldsymbol{A} = \boldsymbol{W}\boldsymbol{H}$，再把伸缩因子放到左侧，比较两种顺序。

先伸缩、后转向 回到 $\boldsymbol{A} = \boldsymbol{W}\boldsymbol{H}$。刚求出的 $\boldsymbol{H}$ 正定，因而可逆，在等式两边右乘 $\boldsymbol{H}^{-1}$，得到正交因子唯一可能的候选 $\boldsymbol{W} = \boldsymbol{A}\boldsymbol{H}^{-1}$。右乘而不是左乘，是由原方程中因子的顺序决定的：$\boldsymbol{H}$ 先作用，要撤销它的伸缩，就要在 $\boldsymbol{A}$ 的右侧作用 $\boldsymbol{H}^{-1}$。

$\boldsymbol{H}^{-1}$ 同样可以沿特征方向写出。$\boldsymbol{H}$ 沿 $\boldsymbol{q}_i$ 伸缩 $\sqrt{\lambda_i}$ 倍，撤销这一伸缩就是沿同一方向乘以 $1/\sqrt{\lambda_i}$。令

$$\boldsymbol{H}^{-1} = \boldsymbol{Q}\,\mathrm{diag}\big(1/\sqrt{\lambda_1}, \dots, 1/\sqrt{\lambda_d}\big)\boldsymbol{Q}^{\top},$$

由 $\boldsymbol{Q}^{\top}\boldsymbol{Q} = \boldsymbol{I}$，它与 $\boldsymbol{H}$ 相乘得 $\boldsymbol{Q}\boldsymbol{I}\boldsymbol{Q}^{\top} = \boldsymbol{I}$，确实是逆矩阵。它也对称正定，记作 $\boldsymbol{S}^{-1/2}$，称为 $\boldsymbol{S}$ 的逆平方根。

定义了 $\boldsymbol{W} = \boldsymbol{A}\boldsymbol{H}^{-1}$ 之后，必须检查它满足原来要求的性质。由 $(\boldsymbol{H}^{-1})^{\top} = (\boldsymbol{H}^{\top})^{-1} = \boldsymbol{H}^{-1}$ 及 $\boldsymbol{A}^{\top}\boldsymbol{A} = \boldsymbol{S} = \boldsymbol{H}^2$，

$$\boldsymbol{W}^{\top}\boldsymbol{W} = \boldsymbol{H}^{-1}\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{H}^{-1} = \boldsymbol{H}^{-1}\boldsymbol{H}^2\boldsymbol{H}^{-1} = \boldsymbol{I},$$

所以 $\boldsymbol{W}$ 正交；又 $\boldsymbol{W}\boldsymbol{H} = \boldsymbol{A}\boldsymbol{H}^{-1}\boldsymbol{H} = \boldsymbol{A}$。正交性和分解等式都成立，存在性才算证完。这样的分解有一个专门的名称。

定义 6.2 极分解 设 $\boldsymbol{A} \in \mathbb{R}^{d\times d}$。若 $\boldsymbol{W}$ 是正交矩阵，$\boldsymbol{H}$ 是对称半正定矩阵，且

$$\begin{aligned} \boldsymbol{A} &= \boldsymbol{W}\boldsymbol{H} \\ \boldsymbol{W}^{\top}\boldsymbol{W} = \boldsymbol{I}, &\quad \boldsymbol{H} = (\boldsymbol{A}^{\top}\boldsymbol{A})^{1/2}, \end{aligned} \tag{6.4}$$

则称 $\boldsymbol{A} = \boldsymbol{W}\boldsymbol{H}$ 为 $\boldsymbol{A}$ 的**极分解**（polar decomposition），也称右极分解，$\boldsymbol{W}$ 称为正交因子，$\boldsymbol{H}$ 称为伸缩因子。

式中 $\boldsymbol{H} = (\boldsymbol{A}^{\top}\boldsymbol{A})^{1/2}$ 并不是额外的要求：由式 (6.1)，任何满足 $\boldsymbol{A} = \boldsymbol{W}\boldsymbol{H}$、$\boldsymbol{W}$ 正交、$\boldsymbol{H}$ 对称半正定的分解都有 $\boldsymbol{H}^2 = \boldsymbol{A}^{\top}\boldsymbol{A}$，再由定理 6.1，$\boldsymbol{H}$ 只能是 $(\boldsymbol{A}^{\top}\boldsymbol{A})^{1/2}$。把上面的推导与验证合在一起，就得到可逆情形的结论。

定理 6.3 可逆矩阵的极分解 设 $\boldsymbol{A} \in \mathbb{R}^{d\times d}$ 可逆，则 $\boldsymbol{A}$ 有极分解，且两个因子都唯一：

$$\boldsymbol{H} = (\boldsymbol{A}^{\top}\boldsymbol{A})^{1/2}, \qquad \boldsymbol{W} = \boldsymbol{A}(\boldsymbol{A}^{\top}\boldsymbol{A})^{-1/2},$$

其中 $\boldsymbol{H}$ 对称正定。

证明 存在性：由第 6.1 节，$\boldsymbol{S}=\boldsymbol{A}^{\top}\boldsymbol{A}$ 对称正定；由定理 6.1，$\boldsymbol{H}=\boldsymbol{S}^{1/2}$ 对称正定，从而可逆；上面已验证 $\boldsymbol{W}=\boldsymbol{A}\boldsymbol{H}^{-1}$ 正交且 $\boldsymbol{W}\boldsymbol{H}=\boldsymbol{A}$。

唯一性：设 $\boldsymbol{A}=\boldsymbol{W}'\boldsymbol{H}'$ 是任一极分解。由式 (6.1)，$\boldsymbol{H}'^{2}=\boldsymbol{S}$，又 $\boldsymbol{H}'$ 对称半正定，由定理 6.1得 $\boldsymbol{H}'=\boldsymbol{S}^{1/2}=\boldsymbol{H}$。$\boldsymbol{H}$ 可逆，在 $\boldsymbol{A}=\boldsymbol{W}'\boldsymbol{H}$ 两边右乘 $\boldsymbol{H}^{-1}$ 得 $\boldsymbol{W}'=\boldsymbol{A}\boldsymbol{H}^{-1}=\boldsymbol{W}$。 ■

由 $\det\boldsymbol{A}=\det\boldsymbol{W}\det\boldsymbol{H}$ 及 $\det\boldsymbol{H}>0$，$\det\boldsymbol{W}$ 与 $\det\boldsymbol{A}$ 同号：$\det\boldsymbol{A}>0$ 时 $\boldsymbol{W}$ 是旋转，$\det\boldsymbol{A}<0$ 时 $\boldsymbol{W}$ 包含一次反射。这正是第 6.1节不限制正交作用类型的原因。

上一节的 Gram 因子也可以由此理解。对可逆的 $\boldsymbol{L}$，$\boldsymbol{L}^{\top}\boldsymbol{L}=\boldsymbol{S}$，所以 $\boldsymbol{L}$ 的极分解是 $\boldsymbol{L}=(\boldsymbol{L}\boldsymbol{S}^{-1/2})\boldsymbol{S}^{1/2}$。$\boldsymbol{L}$ 与 $\boldsymbol{S}^{1/2}$ 恰好相差正交因子 $\boldsymbol{L}\boldsymbol{S}^{-1/2}$，这解释了二者为何给出相同的长度。

现在把贯穿例算完。$\boldsymbol{H}=\operatorname{diag}(3,1)$，所以 $\boldsymbol{H}^{-1}=\operatorname{diag}(1/3,1)$，右乘得

$$\boldsymbol{W}=\boldsymbol{A}\boldsymbol{H}^{-1}=\begin{bmatrix}0&-1\\3&0\end{bmatrix}\begin{bmatrix}1/3&0\\0&1\end{bmatrix}=\begin{bmatrix}0&-1\\1&0\end{bmatrix}.$$

逐项核对：$\boldsymbol{W}^{\top}\boldsymbol{W}=\boldsymbol{I}$；$\boldsymbol{W}\boldsymbol{H}=\left[\begin{smallmatrix}0&-1\\3&0\end{smallmatrix}\right]=\boldsymbol{A}$。$\boldsymbol{W}$ 把 $\boldsymbol{e}_1$ 送到 $\boldsymbol{e}_2$、把 $\boldsymbol{e}_2$ 送到 $-\boldsymbol{e}_1$，是逆时针旋转 90 度。

于是原变换可以读成：先沿 $\boldsymbol{e}_1$ 伸长 3 倍、沿 $\boldsymbol{e}_2$ 保持不变，再整体旋转 90 度。在这个解题过程中，$\boldsymbol{S}$ 是由 $\boldsymbol{A}$ 直接算出的中间量，$\boldsymbol{H}$ 是对 $\boldsymbol{S}$ 开方得到的因子，$\boldsymbol{W}$ 则是撤销伸缩后剩下的因子。

先转向、后伸缩 同一个作用也可以先转向、后伸缩，即求 $\boldsymbol{A}=\boldsymbol{K}\boldsymbol{W}'$，其中 $\boldsymbol{K}$ 对称正定、$\boldsymbol{W}'$ 正交。仿照式 (6.1)，这次从右侧消去正交因子：

$$\boldsymbol{A}\boldsymbol{A}^{\top}=\boldsymbol{K}\boldsymbol{W}'\boldsymbol{W}'^{\top}\boldsymbol{K}^{\top}=\boldsymbol{K}^{2}.$$

所以 $\boldsymbol{K}$ 只能是 $\boldsymbol{A}\boldsymbol{A}^{\top}$ 的正定平方根。$\boldsymbol{A}\boldsymbol{A}^{\top}$ 与 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 一般不同，左右两个伸缩因子也就不同。

两种写法用的是同一个正交因子。由右极分解 $\boldsymbol{A}=\boldsymbol{W}\boldsymbol{H}$，在 $\boldsymbol{H}$ 左侧插入 $\boldsymbol{W}^{\top}\boldsymbol{W}=\boldsymbol{I}$，得

$$\boldsymbol{A}=\boldsymbol{W}\boldsymbol{H}\boldsymbol{W}^{\top}\boldsymbol{W}=(\boldsymbol{W}\boldsymbol{H}\boldsymbol{W}^{\top})\boldsymbol{W}.$$

令 $\boldsymbol{K}=\boldsymbol{W}\boldsymbol{H}\boldsymbol{W}^{\top}$。它对称；由 $\boldsymbol{H}$ 的谱分解，$\boldsymbol{K}=(\boldsymbol{W}\boldsymbol{Q})\boldsymbol{\Lambda}^{1/2}(\boldsymbol{W}\boldsymbol{Q})^{\top}$，而 $\boldsymbol{W}\boldsymbol{Q}$ 正交，所以 $\boldsymbol{K}$ 正定，特征值与 $\boldsymbol{H}$ 相同，特征方向是 $\boldsymbol{H}$ 的特征方向经 $\boldsymbol{W}$ 转过后的方向。又 $\boldsymbol{K}^{2}=\boldsymbol{W}\boldsymbol{H}^{2}\boldsymbol{W}^{\top}=\boldsymbol{W}\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{W}^{\top}=\boldsymbol{A}\boldsymbol{A}^{\top}$，最后一步用了 $\boldsymbol{A}\boldsymbol{A}^{\top}=\boldsymbol{W}\boldsymbol{H}\boldsymbol{H}\boldsymbol{W}^{\top}$。由定理 6.1，$\boldsymbol{K}=(\boldsymbol{A}\boldsymbol{A}^{\top})^{1/2}$。

定理 6.4　左极分解　设 $\boldsymbol{A}\in\mathbb{R}^{d\times d}$ 可逆，$\boldsymbol{A}=\boldsymbol{W}\boldsymbol{H}$ 是它的极分解。则

$$\boldsymbol{A}=\boldsymbol{K}\boldsymbol{W},\qquad \boldsymbol{K}=(\boldsymbol{A}\boldsymbol{A}^{\top})^{1/2}=\boldsymbol{W}\boldsymbol{H}\boldsymbol{W}^{\top},$$

其中 $\boldsymbol{K}$ 对称正定。满足 $\boldsymbol{A}=\boldsymbol{K}'\boldsymbol{W}'$、$\boldsymbol{K}'$ 对称半正定、$\boldsymbol{W}'$ 正交的分解只有这一个，称为 $\boldsymbol{A}$ 的**左极分解**（left polar decomposition）。

证明　存在性已在定理前验证。唯一性：若 $\boldsymbol{A}=\boldsymbol{K}'\boldsymbol{W}'$，则 $\boldsymbol{K}'^{2}=\boldsymbol{A}\boldsymbol{A}^{\top}$，由定理 6.1得 $\boldsymbol{K}'=(\boldsymbol{A}\boldsymbol{A}^{\top})^{1/2}=\boldsymbol{K}$；$\boldsymbol{K}$ 可逆，故 $\boldsymbol{W}'=\boldsymbol{K}^{-1}\boldsymbol{A}=\boldsymbol{K}^{-1}\boldsymbol{K}\boldsymbol{W}=\boldsymbol{W}$。 ■

在贯穿例中，$\boldsymbol{A}\boldsymbol{A}^{\top}=\operatorname{diag}(1,9)$，所以 $\boldsymbol{K}=\operatorname{diag}(1,3)$；也可以由 $\boldsymbol{K}=\boldsymbol{W}\boldsymbol{H}\boldsymbol{W}^{\top}$ 核对：旋转 90 度把 $\boldsymbol{H}$ 沿 $\boldsymbol{e}_1$ 的伸长 3 倍转到沿 $\boldsymbol{e}_2$。直接相乘，

$$\boldsymbol{K}\boldsymbol{W}=\begin{bmatrix}1&0\\0&3\end{bmatrix}\begin{bmatrix}0&-1\\1&0\end{bmatrix}=\begin{bmatrix}0&-1\\3&0\end{bmatrix}=\boldsymbol{A}.$$

两种读法分别是“先沿 $\boldsymbol{e}_1$ 伸长、再旋转”和“先旋转、再沿 $\boldsymbol{e}_2$ 伸长”。伸缩倍数相同，伸缩的方向一个在输入端度量，一个在输出端度量。

与奇异值分解对照，两种顺序的关系更清楚。若 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$，则下一节将验证 $\boldsymbol{W}=\boldsymbol{U}\boldsymbol{V}^{\top}$、$\boldsymbol{H}=\boldsymbol{V}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$，于是 $\boldsymbol{K}=\boldsymbol{W}\boldsymbol{H}\boldsymbol{W}^{\top}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{U}^{\top}$。右伸缩因子沿右奇异向量伸缩，左伸缩因子沿左奇异向量伸缩，倍数都是奇异值。

6.4　奇异与矩形矩阵的极分解

前两节的正交因子由 $\boldsymbol{W}=\boldsymbol{A}\boldsymbol{H}^{-1}$ 求出，这要求 $\boldsymbol{H}$ 可逆，即 $\boldsymbol{A}$ 可逆。本节去掉这个条件：先处理奇异方阵，再处理矩形矩阵。两种情形都借助奇异值分解构造因子，难点在于说明哪些部分仍然唯一。

零伸缩方向上的正交补全　当 $\boldsymbol{A}$ 奇异时，$\boldsymbol{S}=\boldsymbol{A}^{\top}\boldsymbol{A}$ 仍对称半正定，但有零特征值。定理 6.1对半正定矩阵成立，所以沿谱取非负平方根仍能构造唯一的半正定 $\boldsymbol{H}=\boldsymbol{S}^{1/2}$。上一节的做法却在下一步失效：零特征值不能取倒数，$\boldsymbol{H}^{-1}$ 不存在，也就无法由 $\boldsymbol{W}=\boldsymbol{A}\boldsymbol{H}^{-1}$ 得到正交因子。

这时可以直接利用第 5章的奇异值分解。由定理 5.1，方阵 $\boldsymbol{A}$ 可以写成 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$，其中 $\boldsymbol{U},\boldsymbol{V}\in\mathbb{R}^{d\times d}$ 正交，$\boldsymbol{\Sigma}=\operatorname{diag}(\sigma_1,\dots,\sigma_d)$，$\sigma_1\ge\cdots\ge\sigma_d\ge 0$。在 $\boldsymbol{U}$ 与 $\boldsymbol{\Sigma}$ 之间插入 $\boldsymbol{V}^{\top}\boldsymbol{V}=\boldsymbol{I}$，就得到候选

$$\begin{aligned}\boldsymbol{A}&=(\boldsymbol{U}\boldsymbol{V}^{\top})(\boldsymbol{V}\boldsymbol{\Sigma}\boldsymbol{V}^{\top})\\ \boldsymbol{W}&=\boldsymbol{U}\boldsymbol{V}^{\top},\quad \boldsymbol{H}=\boldsymbol{V}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}.\end{aligned}\tag{6.5}$$

定理 6.5 一般方阵的极分解 每个 $\boldsymbol{A} \in \mathbb{R}^{d\times d}$ 都有极分解，式 (6.5)给出其中一个。伸缩因子 $\boldsymbol{H} = (\boldsymbol{A}^{\top}\boldsymbol{A})^{1/2}$ 总是唯一的；正交因子 $\boldsymbol{W}$ 唯一，当且仅当 $\boldsymbol{A}$ 可逆。

证明 先验证式 (6.5)。$\boldsymbol{H} = \boldsymbol{V}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$ 是对称矩阵的正交谱分解，特征值 $\sigma_i \geq 0$，故 $\boldsymbol{H}$ 对称半正定；由 $\boldsymbol{U}^{\top}\boldsymbol{U} = \boldsymbol{I}$ 与 $\boldsymbol{\Sigma}^{\top} = \boldsymbol{\Sigma}$，

$$\boldsymbol{H}^2 = \boldsymbol{V}\boldsymbol{\Sigma}^2\boldsymbol{V}^{\top} = \boldsymbol{V}\boldsymbol{\Sigma}^{\top}\boldsymbol{U}^{\top}\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top} = \boldsymbol{A}^{\top}\boldsymbol{A}.$$

又 $(\boldsymbol{U}\boldsymbol{V}^{\top})^{\top}\boldsymbol{U}\boldsymbol{V}^{\top} = \boldsymbol{V}\boldsymbol{U}^{\top}\boldsymbol{U}\boldsymbol{V}^{\top} = \boldsymbol{I}$，所以 $\boldsymbol{W}$ 正交；而 $\boldsymbol{W}\boldsymbol{H} = \boldsymbol{U}\boldsymbol{V}^{\top}\boldsymbol{V}\boldsymbol{\Sigma}\boldsymbol{V}^{\top} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top} = \boldsymbol{A}$。这就证明了存在性。

$\boldsymbol{H}$ 的唯一性与可逆情形相同：任何极分解都满足式 (6.1)，由定理 6.1，$\boldsymbol{H} = (\boldsymbol{A}^{\top}\boldsymbol{A})^{1/2}$。$\boldsymbol{A}$ 可逆时，$\boldsymbol{W}$ 的唯一性已由定理 6.3给出。

设 $\boldsymbol{A}$ 奇异，则 $\operatorname{rank}\boldsymbol{A} < d$，由定理 5.1知 $\sigma_d = 0$。令 $\boldsymbol{U}'$ 为把 $\boldsymbol{U}$ 的最后一列 $\boldsymbol{u}_d$ 换成 $-\boldsymbol{u}_d$ 所得的矩阵，它仍正交。$\boldsymbol{U}\boldsymbol{\Sigma}$ 的第 i 列是 $\sigma_i\boldsymbol{u}_i$，最后一列因 $\sigma_d = 0$ 而为零，所以 $\boldsymbol{U}'\boldsymbol{\Sigma} = \boldsymbol{U}\boldsymbol{\Sigma}$，从而 $\boldsymbol{A} = \boldsymbol{U}'\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$。按同样的验证，$\boldsymbol{W}' = \boldsymbol{U}'\boldsymbol{V}^{\top}$ 与同一个 $\boldsymbol{H}$ 也构成极分解，而

$$\boldsymbol{W} - \boldsymbol{W}' = (\boldsymbol{U} - \boldsymbol{U}')\boldsymbol{V}^{\top} = 2\boldsymbol{u}_d\boldsymbol{v}_d^{\top} \neq \boldsymbol{0},$$

所以正交因子不唯一。 ■

可逆时，式 (6.5)与定理 6.3给出的是同一对因子，因为两者都是极分解，而可逆情形的极分解唯一。谱开方的路线解释了因子为什么是这个样子；实际计算时，若已经有 SVD，可以直接读出两个因子。

规范部分等距因子 不唯一的原因可以从作用上看清。设 $r = \operatorname{rank}\boldsymbol{A}$。对 $i \leq r$，$\boldsymbol{H}\boldsymbol{v}_i = \sigma_i\boldsymbol{v}_i$ 且 $\sigma_i > 0$，由 $\boldsymbol{A} = \boldsymbol{W}\boldsymbol{H}$ 得 $\boldsymbol{W}\boldsymbol{v}_i = \boldsymbol{A}\boldsymbol{v}_i/\sigma_i = \boldsymbol{u}_i$，正交因子在这些方向上由 $\boldsymbol{A}$ 完全确定。对 $i > r$，$\boldsymbol{H}$ 把 $\boldsymbol{v}_i$ 压成零，$\boldsymbol{A}$ 在这些方向上不提供任何信息。

所以分解中真正由 $\boldsymbol{A}$ 确定的，是正交因子在 $\operatorname{span}\{\boldsymbol{v}_1, \ldots, \boldsymbol{v}_r\} = (\ker\boldsymbol{A})^{\perp}$ 上的作用。把这部分单独取出，在 $\ker\boldsymbol{A}$ 上规定为零，得到

$$\boldsymbol{W}_0 = \boldsymbol{U}_r\boldsymbol{V}_r^{\top} = \sum_{i=1}^{r}\boldsymbol{u}_i\boldsymbol{v}_i^{\top},$$

其中 $\boldsymbol{U}_r$、$\boldsymbol{V}_r$ 是秩分解形式中的因子。它把 $\boldsymbol{v}_i$ 送到 $\boldsymbol{u}_i$（$i \leq r$），把 $\ker\boldsymbol{A}$ 送到零；对 $(\ker\boldsymbol{A})^{\perp}$ 中的 $\boldsymbol{x} = \sum_{i\leq r} c_i\boldsymbol{v}_i$，$\|\boldsymbol{W}_0\boldsymbol{x}\|_2^2 = \sum_{i\leq r} c_i^2 = \|\boldsymbol{x}\|_2^2$。一般地，

若矩阵在其核的正交补上保持长度，就称它为**部分等距**（partial isometry）。$\boldsymbol{W}_0$ 不是正交矩阵，但它在需要保持长度的地方保持长度。

$\boldsymbol{W}_0$ 由 $\boldsymbol{A}$ 唯一确定，不依赖所选的奇异值分解。由 $\boldsymbol{H}=\boldsymbol{V}_r\boldsymbol{\Sigma}_r\boldsymbol{V}_r^{\top}$，$\boldsymbol{W}_0\boldsymbol{H}=\boldsymbol{U}_r\boldsymbol{\Sigma}_r\boldsymbol{V}_r^{\top}=\boldsymbol{A}$。反过来，设矩阵 $\boldsymbol{Z}$ 满足 $\boldsymbol{Z}\boldsymbol{H}=\boldsymbol{A}$ 且在 $\ker\boldsymbol{A}$ 上为零。$\operatorname{range}\boldsymbol{H}=\operatorname{span}\{\boldsymbol{v}_1,\dots,\boldsymbol{v}_r\}$，其中每个 $\boldsymbol{y}=\boldsymbol{H}\boldsymbol{x}$ 都满足 $\boldsymbol{Z}\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}$，所以 $\boldsymbol{Z}$ 在 $\operatorname{range}\boldsymbol{H}$ 上由 $\boldsymbol{A}$ 决定；它在正交补 $\ker\boldsymbol{A}$ 上又规定为零，所以 $\boldsymbol{Z}$ 处处确定，即 $\boldsymbol{Z}=\boldsymbol{W}_0$。称 $\boldsymbol{W}_0$ 为 $\boldsymbol{A}$ 的规范部分等距因子。

全部正交因子都由 $\boldsymbol{W}_0$ 补全得到。记 $\boldsymbol{V}_0=[\boldsymbol{v}_{r+1},\dots,\boldsymbol{v}_d]$、$\boldsymbol{U}_0=[\boldsymbol{u}_{r+1},\dots,\boldsymbol{u}_d]$，它们分别是 $\ker\boldsymbol{A}$ 与 $\operatorname{range}(\boldsymbol{A})^{\perp}$ 的标准正交基。

定理 6.6　奇异方阵的全部正交因子　设 $\boldsymbol{A}\in\mathbb{R}^{d\times d}$，$r=\operatorname{rank}\boldsymbol{A}<d$，记号如上。则正交矩阵 $\boldsymbol{W}$ 满足 $\boldsymbol{A}=\boldsymbol{W}(\boldsymbol{A}^{\top}\boldsymbol{A})^{1/2}$，当且仅当存在 $d-r$ 阶正交矩阵 $\boldsymbol{R}$，使

$$\boldsymbol{W}=\boldsymbol{W}_0+\boldsymbol{U}_0\boldsymbol{R}\boldsymbol{V}_0^{\top}.$$

证明　充分性：$\boldsymbol{U}_0\boldsymbol{R}\boldsymbol{V}_0^{\top}$ 在 $(\ker\boldsymbol{A})^{\perp}$ 上为零，所以 $\boldsymbol{W}\boldsymbol{H}=\boldsymbol{W}_0\boldsymbol{H}=\boldsymbol{A}$。又 $\boldsymbol{W}[\boldsymbol{V}_r,\boldsymbol{V}_0]=[\boldsymbol{U}_r,\boldsymbol{U}_0\boldsymbol{R}]$，右端各列标准正交：$\boldsymbol{U}_r$ 与 $\boldsymbol{U}_0$ 的列分别标准正交且彼此正交，$\boldsymbol{R}$ 正交。所以 $\boldsymbol{W}$ 把标准正交基送到标准正交基，是正交矩阵。

必要性：设 $\boldsymbol{W}$ 正交且 $\boldsymbol{W}\boldsymbol{H}=\boldsymbol{A}$。由前面的分析，$\boldsymbol{W}\boldsymbol{V}_r=\boldsymbol{U}_r$。正交矩阵保持内积，所以 $\boldsymbol{W}\boldsymbol{V}_0$ 的列标准正交，并且与 $\boldsymbol{W}\boldsymbol{V}_r=\boldsymbol{U}_r$ 的列正交，即落在 $\operatorname{range}(\boldsymbol{A})^{\perp}$ 中。于是 $\boldsymbol{W}\boldsymbol{V}_0=\boldsymbol{U}_0\boldsymbol{R}$，其中 $\boldsymbol{R}=\boldsymbol{U}_0^{\top}\boldsymbol{W}\boldsymbol{V}_0$；$\boldsymbol{R}^{\top}\boldsymbol{R}=\boldsymbol{V}_0^{\top}\boldsymbol{W}^{\top}\boldsymbol{U}_0\boldsymbol{U}_0^{\top}\boldsymbol{W}\boldsymbol{V}_0=\boldsymbol{V}_0^{\top}\boldsymbol{W}^{\top}\boldsymbol{W}\boldsymbol{V}_0=\boldsymbol{I}$，这里用到 $\boldsymbol{U}_0\boldsymbol{U}_0^{\top}$ 是到 $\operatorname{range}(\boldsymbol{A})^{\perp}$ 的正交投影，它不改变 $\boldsymbol{W}\boldsymbol{V}_0$ 的列。$\boldsymbol{R}$ 是方阵，所以正交。最后，$\boldsymbol{W}=\boldsymbol{W}[\boldsymbol{V}_r,\boldsymbol{V}_0][\boldsymbol{V}_r,\boldsymbol{V}_0]^{\top}=\boldsymbol{U}_r\boldsymbol{V}_r^{\top}+\boldsymbol{U}_0\boldsymbol{R}\boldsymbol{V}_0^{\top}$。 ■

定理说明，正交因子的全部自由度都来自核：它必须把 $\ker\boldsymbol{A}$ 保长地送到 $\operatorname{range}(\boldsymbol{A})^{\perp}$，至于怎样送，$\boldsymbol{A}$ 没有提供任何信息。核的维数 $d-r$ 越大，可选的 $\boldsymbol{R}$ 越多；可逆时 $d-r=0$，$\boldsymbol{W}=\boldsymbol{W}_0$ 唯一。定理 6.5证明中的变号只是取 $\boldsymbol{R}=-1$（$d-r=1$ 时）或 $\boldsymbol{R}=\operatorname{diag}(1,\dots,1,-1)$ 的特例。这里始终没有定义不存在的 $\boldsymbol{H}^{-1}$，也不能用逐元素取倒数代替矩阵求逆。

示例 6.7　秩一方阵的极分解　用最简单的奇异方阵看一看定理中的自由度。取 $\boldsymbol{A}=\left[\begin{smallmatrix}0&0\\1&0\end{smallmatrix}\right]$，它把 $\boldsymbol{e}_1$ 送到 $\boldsymbol{e}_2$，把 $\boldsymbol{e}_2$ 压成零。伸缩因子照常求出：$\boldsymbol{A}^{\top}\boldsymbol{A}=\operatorname{diag}(1,0)$，所以 $\boldsymbol{H}=\operatorname{diag}(1,0)$。

正交因子在 $\boldsymbol{e}_1$ 方向上被 $\boldsymbol{A}$ 确定：取 $\boldsymbol{v}_1=\boldsymbol{e}_1$、$\boldsymbol{u}_1=\boldsymbol{e}_2$，规范部分等距因子为 $\boldsymbol{W}_0=\boldsymbol{e}_2\boldsymbol{e}_1^{\top}=\left[\begin{smallmatrix}0&0\\1&0\end{smallmatrix}\right]$，恰好就是 $\boldsymbol{A}$ 本身。剩下的是怎样把

核 $\ker \boldsymbol{A} = \operatorname{span}\{\boldsymbol{e}_2\}$ 保长地送到 $\operatorname{range}(\boldsymbol{A})^{\perp} = \operatorname{span}\{\boldsymbol{e}_1\}$。取 $\boldsymbol{V}_0 = \boldsymbol{e}_2$、$\boldsymbol{U}_0 = \boldsymbol{e}_1$，这里 $d - r = 1$，$\boldsymbol{R}$ 只能是 ± 1，于是得到两个正交因子

$$\boldsymbol{W}_{\pm} = \begin{bmatrix} 0 & \pm 1 \\ 1 & 0 \end{bmatrix}.$$

两者都满足 $\boldsymbol{W}_{\pm}\boldsymbol{H} = \boldsymbol{A}$，因为 $\boldsymbol{H}$ 的第二列为零，$\boldsymbol{W}_{\pm}$ 第二列的差别被乘掉了。从几何上看，$\boldsymbol{W}_{+}$ 是关于直线 $x_1 = x_2$ 的反射，$\boldsymbol{W}_{-}$ 是逆时针旋转 90 度，类型都不同；它们只在 $\boldsymbol{e}_1$ 上必须一致，在被压成零的 $\boldsymbol{e}_2$ 方向上，$\boldsymbol{A}$ 不提供任何约束。

矩形矩阵 矩形矩阵 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$ 的输入与输出不在同一空间，不存在把 $\mathbb{R}^d$ 映到 $\mathbb{R}^m$ 的正交矩阵，保长因子只能是列标准正交或行标准正交的矩阵。哪一种可行，取决于哪一端更大。

先设 $m \geq d$，即 $\boldsymbol{A}$ 是高矩阵。取薄奇异值分解 $\boldsymbol{A} = \boldsymbol{U}_d\boldsymbol{\Sigma}_d\boldsymbol{V}^{\top}$，其中 $\boldsymbol{U}_d \in \mathbb{R}^{m\times d}$ 列标准正交，$\boldsymbol{\Sigma}_d = \operatorname{diag}(\sigma_1, \dots, \sigma_d)$，$\boldsymbol{V} \in \mathbb{R}^{d\times d}$ 正交。仿照式 (6.5)，令

$$\boldsymbol{W} = \boldsymbol{U}_d\boldsymbol{V}^{\top} \in \mathbb{R}^{m\times d}, \qquad \boldsymbol{H} = \boldsymbol{V}\boldsymbol{\Sigma}_d\boldsymbol{V}^{\top} \in \mathbb{R}^{d\times d}.$$

则 $\boldsymbol{W}^{\top}\boldsymbol{W} = \boldsymbol{V}\boldsymbol{U}_d^{\top}\boldsymbol{U}_d\boldsymbol{V}^{\top} = \boldsymbol{I}_d$，即 $\boldsymbol{W}$ 的列标准正交，它把 $\mathbb{R}^d$ 保长地映入 $\mathbb{R}^m$；$\boldsymbol{W}\boldsymbol{H} = \boldsymbol{U}_d\boldsymbol{\Sigma}_d\boldsymbol{V}^{\top} = \boldsymbol{A}$。

唯一性的讨论与方阵相同。由 $\boldsymbol{W}^{\top}\boldsymbol{W} = \boldsymbol{I}_d$，仍有 $\boldsymbol{A}^{\top}\boldsymbol{A} = \boldsymbol{H}\boldsymbol{W}^{\top}\boldsymbol{W}\boldsymbol{H} = \boldsymbol{H}^2$，所以 $\boldsymbol{H} = (\boldsymbol{A}^{\top}\boldsymbol{A})^{1/2}$ 唯一。若 $\boldsymbol{A}$ 满列秩，$\boldsymbol{H}$ 可逆，$\boldsymbol{W} = \boldsymbol{A}\boldsymbol{H}^{-1}$ 也唯一；若 $\operatorname{rank}\boldsymbol{A} < d$，同样可以在 $\ker\boldsymbol{A}$ 上改变 $\boldsymbol{W}$，例如把 $\boldsymbol{U}_d$ 中对应零奇异值的一列变号。

再设 $m < d$，即 $\boldsymbol{A}$ 是宽矩阵。这时不存在列标准正交的 $m \times d$ 矩阵，因为 $\mathbb{R}^m$ 中至多有 m 个标准正交向量。改对 $\boldsymbol{A}^{\top}$ 用上面的结论：$\boldsymbol{A}^{\top} = \boldsymbol{W}_1\boldsymbol{H}_1$，$\boldsymbol{W}_1 \in \mathbb{R}^{d\times m}$ 列标准正交，$\boldsymbol{H}_1 = (\boldsymbol{A}\boldsymbol{A}^{\top})^{1/2}$。取转置，

$$\boldsymbol{A} = \boldsymbol{H}_1\boldsymbol{W}_1^{\top},$$

其中 $\boldsymbol{W}_1^{\top} \in \mathbb{R}^{m\times d}$ 行标准正交。这是左极分解的形式：先把 $\mathbb{R}^d$ 正交地投到一个 m 维坐标系中，再在 $\mathbb{R}^m$ 中伸缩。所以对宽矩阵，自然的是左极分解；对高矩阵，自然的是右极分解。

示例 6.8　行向量与列向量的极分解　最小的矩形矩阵是单个列向量或行向量，两种情形正好对应高矩阵和宽矩阵。先看列向量 $\boldsymbol{a} = (3,4)^{\mathsf{T}} \in \mathbb{R}^{2\times 1}$，它把一个数映成平面中的向量。$\boldsymbol{a}^{\mathsf{T}}\boldsymbol{a} = 25$，所以 $\boldsymbol{H} = 5$，$\boldsymbol{W} = \boldsymbol{a}/5 = (0.6, 0.8)^{\mathsf{T}}$，$\boldsymbol{a} = \boldsymbol{W}\boldsymbol{H}$。这个右极分解读作：先把输入的数伸长 5 倍，再保长地放到方向 $(0.6, 0.8)^{\mathsf{T}}$ 上。

转置 $\boldsymbol{a}^{\mathsf{T}} = [3,4]$ 是宽矩阵，把平面向量映成一个数，这时应取左极分解。左伸缩因子来自 $\boldsymbol{a}^{\mathsf{T}}(\boldsymbol{a}^{\mathsf{T}})^{\mathsf{T}} = \boldsymbol{a}^{\mathsf{T}}\boldsymbol{a} = 25$，开方得 5，于是 $\boldsymbol{a}^{\mathsf{T}} = 5 \cdot [0.6, 0.8]$。行标准正交的 $[0.6, 0.8]$ 先读出输入在单位方向 $(0.6, 0.8)^{\mathsf{T}}$ 上的坐标，再乘以 5；保长的一步在前，伸缩在后，顺序与列向量的情形相反。

6.5　矩阵函数的谱表示

前面几节反复把一个标量运算沿特征方向作用到矩阵上。本节把这种做法写成一般定义，检查它与矩阵运算相容，并指出它的适用范围。

沿谱运算的共同方法　回看前面两次构造。求 $\boldsymbol{H}$ 时，我们保持 $\boldsymbol{S}$ 的特征方向，把每个 λ_i 换成 $\sqrt{\lambda_i}$；求 $\boldsymbol{H}^{-1}$ 时，同样保持特征方向，把 λ_i 换成 $1/\sqrt{\lambda_i}$。两次都是“方向不动，只对特征值作用一个标量函数”。把这个实际用过的操作归纳出来，就得到对称矩阵的函数。

设实对称矩阵 $\boldsymbol{S}$ 有正交谱分解 $\boldsymbol{S} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathsf{T}}$。按第 4.3.3节，把同一特征值的项合并，可以写成 $\boldsymbol{S} = \sum_{\lambda} \lambda \boldsymbol{P}_{\lambda}$，求和遍历 $\boldsymbol{S}$ 的不同特征值，$\boldsymbol{P}_{\lambda}$ 是到特征空间 $\ker(\boldsymbol{S} - \lambda \boldsymbol{I})$ 的正交投影，满足 $\boldsymbol{P}_{\lambda}\boldsymbol{P}_{\mu} = \boldsymbol{0}$（$\lambda \neq \mu$）、$\boldsymbol{P}_{\lambda}^2 = \boldsymbol{P}_{\lambda}$ 及 $\sum_{\lambda} \boldsymbol{P}_{\lambda} = \boldsymbol{I}$。

定义 6.9　对称矩阵的谱函数　设 $\boldsymbol{S} \in \mathbb{R}^{d\times d}$ 实对称，f 是定义在 $\boldsymbol{S}$ 全部特征值上的实函数。令

$$
\begin{aligned}
f(\boldsymbol{S}) &= \boldsymbol{Q}\,\mathrm{diag}\big(f(\lambda_1), \dots, f(\lambda_d)\big)\boldsymbol{Q}^{\mathsf{T}} \\
&= \sum_{\lambda} f(\lambda)\boldsymbol{P}_{\lambda},
\end{aligned}
\tag{6.6}
$$

称为由 f 沿谱定义的**矩阵函数**（matrix function）。

两种写法相等：按列展开，第一式是 $\sum_i f(\lambda_i)\boldsymbol{q}_i\boldsymbol{q}_i^{\mathsf{T}}$，把 $\lambda_i = \lambda$ 的项合并，$\sum_{\lambda_i=\lambda} \boldsymbol{q}_i\boldsymbol{q}_i^{\mathsf{T}} = \boldsymbol{P}_{\lambda}$，就得到第二式。第二式只涉及特征值和谱投影，而谱投影由 $\boldsymbol{S}$ 唯一确定，所以 $f(\boldsymbol{S})$ 与重根空间内基的选取无关，定义是良好的。

$f(z)=\sqrt{z}$ 时，它回到第 6.2节的 $\boldsymbol{S}^{1/2}$；$f(z)=1/\sqrt{z}$ 时，回到第 6.3节的 $\boldsymbol{S}^{-1/2}$。前面那些构造在这里得到总结，而不是反过来，必须先建立一般的矩阵函数才能解出 $\boldsymbol{H}$ 与 $\boldsymbol{W}$。

推广之后要检查它与已有的矩阵运算相容，否则同一个记号会有两种含义。

引理 6.10　谱函数与矩阵运算相容　设 $\boldsymbol{S}$ 实对称，f,g 定义在 $\boldsymbol{S}$ 的全部特征值上。

1. 对实系数多项式 $p(z)=\sum_{k=0}^{m}c_k z^k$，按矩阵幂与加法算出的 $\sum_k c_k\boldsymbol{S}^k$ 等于式 (6.6)定义的 $p(\boldsymbol{S})$。
2. $f(\boldsymbol{S})+g(\boldsymbol{S})=(f+g)(\boldsymbol{S})$，$f(\boldsymbol{S})g(\boldsymbol{S})=(fg)(\boldsymbol{S})$。
3. 若 f 在全部特征值上不为零，则 $f(\boldsymbol{S})$ 可逆，且 $f(\boldsymbol{S})^{-1}=(1/f)(\boldsymbol{S})$；特别地，$\boldsymbol{S}$ 可逆时取 $f(z)=1/z$ 即得 $\boldsymbol{S}^{-1}$。

证明　先证第二条。加法由式 (6.6)的第二式直接得到。乘法利用谱投影的正交关系：

$$f(\boldsymbol{S})g(\boldsymbol{S})=\sum_{\lambda}\sum_{\mu}f(\lambda)g(\mu)\boldsymbol{P}_\lambda\boldsymbol{P}_\mu=\sum_{\lambda}f(\lambda)g(\lambda)\boldsymbol{P}_\lambda=(fg)(\boldsymbol{S}),$$

中间一步用到 $\lambda\neq\mu$ 时 $\boldsymbol{P}_\lambda\boldsymbol{P}_\mu=\boldsymbol{0}$，以及 $\boldsymbol{P}_\lambda^2=\boldsymbol{P}_\lambda$。

第一条：常数函数 1 给出 $\sum_\lambda\boldsymbol{P}_\lambda=\boldsymbol{I}=\boldsymbol{S}^0$，恒等函数 z 给出 $\sum_\lambda\lambda\boldsymbol{P}_\lambda=\boldsymbol{S}$。由乘法规则对 k 归纳，z^k 给出 $\boldsymbol{S}^k$；再由加法规则（数乘同理）按系数相加，得到 $p(\boldsymbol{S})=\sum_k c_k\boldsymbol{S}^k$。

第三条：由乘法规则，$f(\boldsymbol{S})\,(1/f)(\boldsymbol{S})=(f\cdot 1/f)(\boldsymbol{S})$，即常数函数 1 作用的结果 $\boldsymbol{I}$；两个因子的顺序交换后同理。$f(z)=1/z$ 时，$(1/f)(z)=z$，于是 $(1/z)(\boldsymbol{S})$ 是 $\boldsymbol{S}$ 的逆。 ∎

第一条也可以直接看出：连乘 $\boldsymbol{S}^k=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\top}\cdots\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\top}$ 时相邻的 $\boldsymbol{Q}^{\top}\boldsymbol{Q}$ 相消，得 $\boldsymbol{S}^k=\boldsymbol{Q}\boldsymbol{\Lambda}^k\boldsymbol{Q}^{\top}$。所以对多项式而言，沿谱作用与按矩阵运算计算是一回事；定义 6.9只是把这个事实推广到一般的 f。由第二条，$(\sqrt{z})^2=z$ 给出 $(\boldsymbol{S}^{1/2})^2=\boldsymbol{S}$，$\sqrt{z}\cdot(1/\sqrt{z})=1$ 给出 $\boldsymbol{S}^{1/2}\boldsymbol{S}^{-1/2}=\boldsymbol{I}$，与前面的直接验证一致。

矩阵函数沿特征方向作用，而不是对每个元素作用。下面的例子对照这两种做法。

示例 6.11　矩阵平方根与逐元素开方　取示例 4.22的 $\boldsymbol{S} = \left[\begin{smallmatrix} 2 & 1 \\ 1 & 2 \end{smallmatrix}\right] = 3\boldsymbol{q}_1\boldsymbol{q}_1^{\top} + \boldsymbol{q}_2\boldsymbol{q}_2^{\top}$，其中 $\boldsymbol{q}_1 = (1,1)^{\top}/\sqrt{2}$，$\boldsymbol{q}_2 = (1,-1)^{\top}/\sqrt{2}$。按式 (6.6)取 $f(z) = \sqrt{z}$，保持两个投影不变，只把系数 3 与 1 换成平方根：

$$\boldsymbol{S}^{1/2} = \sqrt{3}\,\boldsymbol{q}_1\boldsymbol{q}_1^{\top} + \boldsymbol{q}_2\boldsymbol{q}_2^{\top} = \frac{1}{2}\begin{bmatrix} \sqrt{3}+1 & \sqrt{3}-1 \\ \sqrt{3}-1 & \sqrt{3}+1 \end{bmatrix}.$$

为了与后面的逐元素做法比较，直接计算它的平方：对角元为 $\frac{1}{4}\left[(\sqrt{3}+1)^2+(\sqrt{3}-1)^2\right] = \frac{1}{4}\cdot 8 = 2$，非对角元为 $\frac{1}{4}\cdot 2(\sqrt{3}+1)(\sqrt{3}-1) = \frac{1}{4}\cdot 4 = 1$，所以 $(\boldsymbol{S}^{1/2})^2 = \boldsymbol{S}$。同样取 $f(z) = 1/\sqrt{z}$，得逆平方根

$$\boldsymbol{S}^{-1/2} = \frac{1}{\sqrt{3}}\boldsymbol{q}_1\boldsymbol{q}_1^{\top} + \boldsymbol{q}_2\boldsymbol{q}_2^{\top} = \frac{1}{2\sqrt{3}}\begin{bmatrix} \sqrt{3}+1 & 1-\sqrt{3} \\ 1-\sqrt{3} & \sqrt{3}+1 \end{bmatrix}.$$

若改为对每个元素开方，得到的矩阵平方以后是

$$\begin{bmatrix} \sqrt{2} & 1 \\ 1 & \sqrt{2} \end{bmatrix}^2 = \begin{bmatrix} 3 & 2\sqrt{2} \\ 2\sqrt{2} & 3 \end{bmatrix} \neq \boldsymbol{S}.$$

差别在于矩阵乘法会把不同元素混合起来：平方的每个元素是一行与一列的内积，而不是单个元素的平方。沿特征方向作用时，各方向在乘法下互不混合，开方才与平方相容；逐元素开方没有这种结构，所以得不到 $\boldsymbol{S}$。

固定的矩阵只有有限个特征值，所以式 (6.6)只需要 f 在这些点上的值，不要求 f 连续，也不需要矩阵级数或微分。

还要把沿谱构造的矩阵函数与第 18章研究的一般矩阵输入映射区分开。行列式 $\boldsymbol{X} \mapsto \det \boldsymbol{X}$、矩阵乘法 $(\boldsymbol{X},\boldsymbol{Y}) \mapsto \boldsymbol{X}\boldsymbol{Y}$、求逆等都以矩阵为输入，范围比 $\boldsymbol{S} \mapsto f(\boldsymbol{S})$ 广得多。

即使研究 $\boldsymbol{S} \mapsto f(\boldsymbol{S})$ 本身的微分，扰动 $\boldsymbol{E}$ 一般也不保持 $\boldsymbol{S}$ 的特征方向，不能直接套用标量求导公式。例如 $f(z) = z^2$，

$$(\boldsymbol{S}+\boldsymbol{E})^2 - \boldsymbol{S}^2 = \boldsymbol{S}\boldsymbol{E} + \boldsymbol{E}\boldsymbol{S} + \boldsymbol{E}^2,$$

一阶部分是 $\boldsymbol{S}\boldsymbol{E} + \boldsymbol{E}\boldsymbol{S}$；只有 $\boldsymbol{S}$ 与 $\boldsymbol{E}$ 可交换时，它才化为标量公式对应的 $2\boldsymbol{S}\boldsymbol{E}$。

在已知分解上作用谱函数 谱函数的定义只要求一组正交的特征方向，所以手中已有的分解可以直接使用。若 $\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\top}$，而 $\boldsymbol{Z}$ 是正交矩阵，则 $\boldsymbol{Z}\boldsymbol{S}\boldsymbol{Z}^{\top}=(\boldsymbol{Z}\boldsymbol{Q})\boldsymbol{\Lambda}(\boldsymbol{Z}\boldsymbol{Q})^{\top}$ 也是正交谱分解，于是

$$f(\boldsymbol{Z}\boldsymbol{S}\boldsymbol{Z}^{\top})=\boldsymbol{Z}f(\boldsymbol{S})\boldsymbol{Z}^{\top}.$$

也就是说，先用正交矩阵转动、再作用谱函数，与先作用谱函数、再转动，结果相同。第 6.3节的左伸缩因子也可以这样得到：由 $\boldsymbol{A}\boldsymbol{A}^{\top}=\boldsymbol{W}\boldsymbol{H}\boldsymbol{H}\boldsymbol{W}^{\top}=\boldsymbol{W}(\boldsymbol{A}^{\top}\boldsymbol{A})\boldsymbol{W}^{\top}$,取 $f(z)=\sqrt{z}$ 得 $\boldsymbol{K}=(\boldsymbol{A}\boldsymbol{A}^{\top})^{1/2}=\boldsymbol{W}(\boldsymbol{A}^{\top}\boldsymbol{A})^{1/2}\boldsymbol{W}^{\top}=\boldsymbol{W}\boldsymbol{H}\boldsymbol{W}^{\top}$。

奇异值分解同样提供现成的谱分解。若 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$，则 $\boldsymbol{A}^{\top}\boldsymbol{A}=\boldsymbol{V}(\boldsymbol{\Sigma}^{\top}\boldsymbol{\Sigma})\boldsymbol{V}^{\top}$，$\boldsymbol{A}\boldsymbol{A}^{\top}=\boldsymbol{U}(\boldsymbol{\Sigma}\boldsymbol{\Sigma}^{\top})\boldsymbol{U}^{\top}$，所以

$$f(\boldsymbol{A}^{\top}\boldsymbol{A})=\boldsymbol{V}f(\boldsymbol{\Sigma}^{\top}\boldsymbol{\Sigma})\boldsymbol{V}^{\top},\qquad f(\boldsymbol{A}\boldsymbol{A}^{\top})=\boldsymbol{U}f(\boldsymbol{\Sigma}\boldsymbol{\Sigma}^{\top})\boldsymbol{U}^{\top},$$

其中 f 作用于对角矩阵的各个对角元。取 $f(z)=\sqrt{z}$，就得到 $\boldsymbol{H}=\boldsymbol{V}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$ 与 $\boldsymbol{K}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{U}^{\top}$。可逆方阵再取 $f(z)=1/\sqrt{z}$，得 $\boldsymbol{W}=\boldsymbol{A}(\boldsymbol{A}^{\top}\boldsymbol{A})^{-1/2}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}\boldsymbol{V}\boldsymbol{\Sigma}^{-1}\boldsymbol{V}^{\top}=\boldsymbol{U}\boldsymbol{V}^{\top}$，与式 (6.5)一致。

实幂与对数的补充例子 对正定 $\boldsymbol{S}$，全部 $\lambda_i>0$，任意实数 α 都使 z^{α} 在谱上有定义，于是

$$\boldsymbol{S}^{\alpha}=\boldsymbol{Q}\,\mathrm{diag}(\lambda_1^{\alpha},\dots,\lambda_d^{\alpha})\boldsymbol{Q}^{\top}.$$

由引理 6.10，$\boldsymbol{S}^{\alpha}\boldsymbol{S}^{\beta}=\boldsymbol{S}^{\alpha+\beta}$。特别地，对正整数 m，$(\boldsymbol{S}^{1/m})^{m}=\boldsymbol{S}$，即把非负伸缩分成 m 次相同的作用时，每次沿各主方向伸缩 $\lambda_i^{1/m}$ 倍；$\boldsymbol{S}^{1/m}$ 本身对称正定，因为它的谱分解中特征值 $\lambda_i^{1/m}>0$。这里只用到它是 $\boldsymbol{X}^{m}=\boldsymbol{S}$ 的一个对称正定解，本节不讨论 $m>2$ 时这类解的唯一性。

零特征值限制了可用的幂。若 $\boldsymbol{S}$ 半正定但有零特征值，$\alpha>0$ 时 $0^{\alpha}=0$，$\boldsymbol{S}^{\alpha}$ 仍有实值的谱定义；$\alpha<0$ 时 0^{α} 没有定义，负幂不能沿用。前面平方根只要求半正定、逆平方根却要求正定，正是这一区别。负特征值则使平方根、对数等运算失去实值定义，例如 $\sqrt{-1}$ 不是实数，所以本节的实幂与对数只对半正定或正定矩阵使用。

对正定 $\boldsymbol{S}$ 还可以取 $f(z)=\log z$，得到**矩阵对数**（matrix logarithm）

$$\log\boldsymbol{S}=\boldsymbol{Q}\,\mathrm{diag}(\log\lambda_1,\dots,\log\lambda_d)\boldsymbol{Q}^{\top}.$$

它记录的是各主方向上伸缩倍数的对数：$\log\lambda_i>0$ 表示沿 $\boldsymbol{q}_i$ 拉长，$\log\lambda_i<0$ 表示压缩。上式本身就是对称矩阵 $\log\boldsymbol{S}$ 的正交谱分解，特征值为 $\log\lambda_i$。

对数与指数互为逆映射。由定义 6.9与基的选取无关，可以用这组 $\boldsymbol{Q}$ 对 $\log\boldsymbol{S}$ 作用 $f(z)=e^{z}$（矩阵指数在本节也按式 (6.6)沿谱定义），得 $e^{\log\boldsymbol{S}}=\boldsymbol{Q}\,\mathrm{diag}(e^{\log\lambda_i})\boldsymbol{Q}^{\top}=\boldsymbol{S}$。反过来，对任意实对称 $\boldsymbol{T}=\boldsymbol{Q}\,\mathrm{diag}(\mu_i)\boldsymbol{Q}^{\top}$，$e^{\boldsymbol{T}}=$

$\boldsymbol{Q}\,\mathrm{diag}(e^{\mu_i})\boldsymbol{Q}^{\top}$ 是特征值全为正的对称矩阵，即正定，同理 $\log e^{\boldsymbol{T}} = \boldsymbol{T}$。所以在沿谱的定义下，log 与 $e^{(\cdot)}$ 在正定矩阵与实对称矩阵之间互为逆映射。$\boldsymbol{S}$ 有零特征值时 $\log 0$ 无定义，这一定义不能使用。

要区分矩阵 $\log \boldsymbol{S}$ 与标量 $\log\det \boldsymbol{S}$。由 $\det \boldsymbol{S} = \det \boldsymbol{\Lambda} = \prod_i \lambda_i$ 及迹的循环性，

$$\log\det \boldsymbol{S} = \sum_{i=1}^{d} \log \lambda_i = \mathrm{tr}(\boldsymbol{Q}\,\mathrm{diag}(\log \lambda_i)\boldsymbol{Q}^{\top}) = \mathrm{tr}(\log \boldsymbol{S}).$$

左端是一个数，$\log \boldsymbol{S}$ 是 d 阶矩阵，二者通过迹联系。对数在本节只是谱函数的又一个例子，不参与极分解的证明。第 18.5节求 $\log\det$ 的微分时，使用的是行列式的微分与标量对数的链式法则，并不以矩阵对数的微分为前提。

6.6 本章小结

本章开头问：能否把一个线性作用分成沿正交方向的伸缩与保长的转向？对可逆方阵，答案完全确定。由正交因子保持长度，$\boldsymbol{A} = \boldsymbol{W}\boldsymbol{H}$ 迫使 $\boldsymbol{H}^2 = \boldsymbol{A}^{\top}\boldsymbol{A}$；沿 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 的谱取正平方根，得到唯一的正定伸缩因子 $\boldsymbol{H} = (\boldsymbol{A}^{\top}\boldsymbol{A})^{1/2}$，再由 $\boldsymbol{W} = \boldsymbol{A}\boldsymbol{H}^{-1}$ 得到唯一的正交因子。$\boldsymbol{W}$ 的行列式与 $\boldsymbol{A}$ 同号，所以它可能包含反射。

伸缩与转向的顺序可以交换。左极分解 $\boldsymbol{A} = \boldsymbol{K}\boldsymbol{W}$ 使用同一个正交因子，伸缩因子换成 $\boldsymbol{K} = (\boldsymbol{A}\boldsymbol{A}^{\top})^{1/2} = \boldsymbol{W}\boldsymbol{H}\boldsymbol{W}^{\top}$：伸缩倍数不变，伸缩方向从输入端转到输出端。用奇异值分解表示，$\boldsymbol{W} = \boldsymbol{U}\boldsymbol{V}^{\top}$、$\boldsymbol{H} = \boldsymbol{V}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$、$\boldsymbol{K} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{U}^{\top}$。

奇异方阵仍有极分解，伸缩因子仍唯一，正交因子则不唯一。由 $\boldsymbol{A}$ 确定的只有规范部分等距因子 $\boldsymbol{W}_0 = \boldsymbol{U}_r\boldsymbol{V}_r^{\top}$，即正交因子在 $(\ker \boldsymbol{A})^{\perp}$ 上的作用；全部正交因子是 $\boldsymbol{W}_0 + \boldsymbol{U}_0\boldsymbol{R}\boldsymbol{V}_0^{\top}$，自由度来自怎样把核保长地送到值域的正交补。矩形矩阵的保长因子只能是列标准正交（高矩阵，右极分解）或行标准正交（宽矩阵，左极分解）的矩阵。

开方与求逆都是“方向不动，只改变特征值”，由此得到对称矩阵的谱函数 $f(\boldsymbol{S}) = \sum_{\lambda} f(\lambda)\boldsymbol{P}_{\lambda}$。它与基的选取无关，与多项式运算、乘法和求逆相容，只需 f 在特征值上有定义；零特征值排除了负幂、逆平方根与对数，负特征值排除了实平方根与对数。已有的谱分解或奇异值分解可以直接用来计算这些函数。

极分解的正交因子在 Frobenius 范数下是离 $\boldsymbol{A}$ 最近的正交矩阵，这一最优性在第 15章证明。随后转向误差：第 7章用奇异值度量输入误差的放大，并估计特征值、奇异值与特征子空间受矩阵扰动时的变化。

第 7 章

条件数与谱扰动

前三章为线性作用找到了便于理解的表示。实际使用这些表示时，数据几乎从不精确：输入向量来自测量，矩阵本身来自样本估计或经过舍入。本章要回答，在只知道误差大小上限的情况下，由手中的数据算出的结论还有多可靠。

误差可以出现在两个位置，问题也随之分成两类。第一类固定矩阵，只让输入带误差：输出最多变化多少，哪些输入方向最敏感？第二类让矩阵本身带误差：由手中矩阵算出的特征值、奇异值、秩和特征子空间，哪些对真实矩阵仍然成立？

第 7.1节处理第一类问题。它先由线性性写出精确的输出增量，再分别在绝对尺度与相对尺度下对扰动方向取最坏值，得到绝对条件数、相对条件数与矩阵条件数 $\kappa_2 = \sigma_{\max}/\sigma_{\min}$。第 7.2节处理第二类问题。对称矩阵的特征值和任意矩阵的奇异值都有不依赖谱分离的误差区间；特征子空间的偏转还要用谱隙控制；一般方阵的特征值则取决于特征基是否接近退化。

本章依赖第 4章的谱定理与 Schur 形，以及第 5章由奇异值读出的范数和秩。所有结论都是有限扰动下的界，对任意大小的误差成立，只用代数恒等式、范数不等式和维数论证，不需要微分。

这些结论与后面几章分工如下。第 14章把输出换成线性方程的解，并区分数据误差与算法误差。第 18章建立矩阵函数的微分公式，第 19章说明特征值等解映射何时可微；沿指定方向的一阶响应、局部条件数和余项界，在第 20章统一讨论。

7.1 线性作用的误差放大与条件数

本节固定矩阵 $\boldsymbol{A}$，只让输入带误差。理想输入是 $\boldsymbol{x}$，实际只能测到 $\boldsymbol{x}+\boldsymbol{h}$，输出 $\boldsymbol{A}(\boldsymbol{x}+\boldsymbol{h})$ 与理想输出 $\boldsymbol{A}\boldsymbol{x}$ 相差多少？允许范围内的输入增量 $\boldsymbol{h}$ 称为**扰动**（perturbation）。

回答分三步。先由线性性写出精确的输出增量，用误差预算得到绝对误差的上界，并找出达到上界的方向。再固定输入 $\boldsymbol{x}$，比较增量占原量的比

例，得到相对条件数；它说明同一个矩阵在不同输入处的敏感程度可以很不一样。最后对输入也取最坏值，得到只依赖矩阵的条件数，并用奇异值说明它比较的是最强与最弱作用的差异。

除特别说明外，向量使用欧氏范数，矩阵使用相应的谱范数。本节讨论的是输入数据的误差怎样传播，矩阵本身和计算过程都视为精确；矩阵本身带误差的情形在下一节讨论，求解算法在计算中引入的误差由第 14章另行讨论。

7.1.1 输入扰动与输出误差

设理想输出为 $\boldsymbol{y} = \boldsymbol{A}\boldsymbol{x}$，其中 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 固定。实际输入为 $\boldsymbol{x} + \boldsymbol{h}$ 时，输出的精确变化是

$$\Delta \boldsymbol{y} = \boldsymbol{A}(\boldsymbol{x} + \boldsymbol{h}) - \boldsymbol{A}\boldsymbol{x} = \boldsymbol{A}\boldsymbol{h}.$$

这一等式只用到矩阵乘法的分配律，对任意大小的 $\boldsymbol{h}$ 都成立，不需要微分，也不要求扰动很小。输出增量与基点 $\boldsymbol{x}$ 无关，只由扰动 $\boldsymbol{h}$ 决定。

实际中通常不知道 $\boldsymbol{h}$ 本身，只知道误差的预算：给定 $\eta \geq 0$，已知 $\|\boldsymbol{h}\|_2 \leq \eta$。于是要回答两个问题：输出误差 $\|\boldsymbol{A}\boldsymbol{h}\|_2$ 有什么可靠的上界；哪些扰动方向会达到或接近这个上界。

输入与输出的**绝对误差**（absolute error）分别是增量的长度 $\|\boldsymbol{h}\|_2$ 与 $\|\boldsymbol{A}\boldsymbol{h}\|_2$。误差预算只限制 $\|\boldsymbol{h}\|_2$，不限制方向，所以可靠的误差界必须对所有方向成立，由最坏的方向决定。第 5章的奇异值分解恰好给出最坏的方向。

定理 7.1　线性作用的绝对误差界　设 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 的最大奇异值为 $\sigma_{\max}(\boldsymbol{A})$，对应的单位右奇异向量为 $\boldsymbol{v}_1$。对任意 $\boldsymbol{h} \in \mathbb{R}^n$，

$$\|\boldsymbol{A}\boldsymbol{h}\|_2 \leq \sigma_{\max}(\boldsymbol{A})\|\boldsymbol{h}\|_2,$$

且 $\boldsymbol{h} = \eta \boldsymbol{v}_1$ 时等号成立。因此在误差预算 $\|\boldsymbol{h}\|_2 \leq \eta$ 下，$\sigma_{\max}(\boldsymbol{A})\eta$ 是输出绝对误差的上界，并且不存在更小的常数 c 使 $\|\boldsymbol{A}\boldsymbol{h}\|_2 \leq c\eta$ 对所有这样的 $\boldsymbol{h}$ 成立。

证明　把 $\boldsymbol{h}$ 按右奇异向量展开为 $\boldsymbol{h} = \sum_i c_i \boldsymbol{v}_i$，则 $\|\boldsymbol{A}\boldsymbol{h}\|_2^2 = \sum_i \sigma_i^2 c_i^2 \leq \sigma_{\max}^2 \sum_i c_i^2 = \sigma_{\max}^2 \|\boldsymbol{h}\|_2^2$，这就是不等式。取 $\boldsymbol{h} = \eta \boldsymbol{v}_1$ 时，$\boldsymbol{A}\boldsymbol{h} = \eta\sigma_{\max}\boldsymbol{u}_1$，长度恰为 $\sigma_{\max}\eta$。若 $c < \sigma_{\max}$ 且 $\eta > 0$，这个扰动满足预算却有 $\|\boldsymbol{A}\boldsymbol{h}\|_2 > c\eta$；$\eta = 0$ 时结论平凡。 ■

这个界对每个扰动都成立，而且由最强的右奇异方向 $\boldsymbol{v}_1$ 达到。其他方向的放大较小：沿右奇异方向 $\boldsymbol{v}_i$ 扰动时，输出误差恰为 $\sigma_i\|\boldsymbol{h}\|_2$；若 $\boldsymbol{A}$ 有

非零零空间，沿零空间的扰动完全不影响输出。所以绝对误差的放大倍数随扰动方向变化，误差界取的是最坏情形。

7.1.2 固定输入处的条件数

上一小节用绝对误差比较输入与输出。对非零扰动 $\boldsymbol{h}$，绝对误差之比 $\|\boldsymbol{A}\boldsymbol{h}\|_2/\|\boldsymbol{h}\|_2$ 只依赖扰动的方向：把 $\boldsymbol{h}$ 换成 $c\boldsymbol{h}$（$c \neq 0$）时，分子与分母同乘 $|c|$。它也与基点 $\boldsymbol{x}$ 无关。这个比值在全部非零扰动上的上确界就是第 3.3.4节的诱导范数 $\|\boldsymbol{A}\|_2 = \sigma_{\max}(\boldsymbol{A})$，称为线性作用 $\boldsymbol{x} \mapsto \boldsymbol{A}\boldsymbol{x}$ 在任一点处的**绝对条件数**（absolute condition number）。对线性作用，各点的绝对条件数都相同。

当量本身有尺度时，更常用增量占原量的比例。在 $\boldsymbol{x} \neq \boldsymbol{0}$ 且 $\boldsymbol{A}\boldsymbol{x} \neq \boldsymbol{0}$ 时，输入与输出的**相对误差**（relative error）分别是

$$\frac{\|\boldsymbol{h}\|_2}{\|\boldsymbol{x}\|_2}, \qquad \frac{\|\boldsymbol{A}\boldsymbol{h}\|_2}{\|\boldsymbol{A}\boldsymbol{x}\|_2}.$$

把输入和扰动同乘一个非零常数，输出和输出增量也同乘这个常数，两端的相对误差都不变，所以相对误差反映的是变化占原有量的比例。但参照量为零时它没有定义，例如 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{0}$ 时只能报告输出的绝对误差；参照量接近零时，很小的绝对变化也会造成很大的相对误差，这时应同时报告绝对误差。选用哪种范数、两端各按绝对还是相对尺度比较，都属于问题本身的规定；规定不同，得到的敏感程度一般也不同。

即使规定相同，同一个矩阵在不同的基点和扰动方向上，相对误差的放大也可以很不一样。

示例 7.2　对角矩阵的两种基点　取 $\boldsymbol{A} = \operatorname{diag}(1, s)$，$0 < s < 1$，误差预算 $\eta > 0$。这个矩阵保持第一个坐标、把第二个坐标压缩为 s 倍；我们让基点与扰动分别落在两个坐标方向上，比较两种搭配。

先取 $\boldsymbol{x} = \boldsymbol{e}_2$、$\boldsymbol{h} = \eta\boldsymbol{e}_1$。此时 $\boldsymbol{A}\boldsymbol{x} = s\boldsymbol{e}_2$，$\boldsymbol{A}\boldsymbol{h} = \eta\boldsymbol{e}_1$，输入与输出的绝对误差都是 η。输入相对误差为 $\eta/1 = \eta$，输出相对误差却是 η/s，放大了 $1/s$ 倍。原因是理想输出被压缩到原来的 s 倍，分母变小了，而扰动所在的 $\boldsymbol{e}_1$ 方向没有被压缩。

保持同一矩阵，改取 $\boldsymbol{x} = \boldsymbol{e}_1$、$\boldsymbol{h} = \eta\boldsymbol{e}_2$。此时 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{e}_1$，$\boldsymbol{A}\boldsymbol{h} = s\eta\boldsymbol{e}_2$，输入相对误差为 η，输出相对误差为 $s\eta$，两者之比为 $s < 1$，误差反而被缩小。

两种取法用的是同一个矩阵，相对误差之比却从 $1/s$ 变成 s。所以谈论矩阵对相对误差的放大时，必须说明基点和扰动方向，或者对它们取最坏情形；下面先对扰动方向取最坏情形，下一小节再对基点取最坏情形。

相对误差的放大也不只来自矩阵对不同方向压缩程度的差别。理想输出本身很小时，即使绝对误差没有被放大，相对误差也会被放大，最常见的情形是两个相近的数相减。

示例 7.3　加法中的抵消　取行矩阵 $\boldsymbol{A} = \begin{bmatrix} 1 & 1 \end{bmatrix}$，它把输入的两个分量相加。理想输入为 $\boldsymbol{x} = (1.0001, -1.0000)^{\mathsf{T}}$，两个分量各带至多 5×10^{-5} 的绝对误差，即扰动 $\boldsymbol{h} = (h_1, h_2)^{\mathsf{T}}$ 满足 $|h_1|, |h_2| \le 5\times10^{-5}$。理想输出为 $\boldsymbol{A}\boldsymbol{x} = 10^{-4}$，输出的精确增量为 $\boldsymbol{A}\boldsymbol{h} = h_1 + h_2$。由三角不等式，

$$|h_1 + h_2| \le |h_1| + |h_2| \le 10^{-4},$$

取 $h_1 = h_2 = 5\times10^{-5}$ 时等号成立。输出的绝对误差至多是 10^{-4}，并不比输入误差大多少，但理想输出本身也只有 10^{-4}，所以输出的相对误差可达

$$\frac{10^{-4}}{10^{-4}} = 1,$$

即结果可能连第一位有效数字都不可靠。再看输入端：$\|\boldsymbol{h}\|_2 \le \sqrt{2}\times 5\times10^{-5}$，$\|\boldsymbol{x}\|_2 \approx \sqrt{2}$，输入的相对误差至多约为 5×10^{-5}。两相比较，相对误差被放大约 2×10^{4} 倍，而放大完全来自分母 $\|\boldsymbol{A}\boldsymbol{x}\|_2$ 因抵消而变小。

这里只用了精确增量与三角不等式。放大也不是算法造成的舍入误差：即使加法精确执行，输入误差本身就使输出的相对误差这样放大，这是问题在相对尺度下的敏感性。

现在固定基点 $\boldsymbol{x}$，两端都用相对尺度，再对扰动方向取最坏情形。

定义 7.4　线性作用的相对条件数　设 $\boldsymbol{x} \neq \boldsymbol{0}$ 且 $\boldsymbol{A}\boldsymbol{x} \neq \boldsymbol{0}$。称

$$\kappa_{\mathrm{rel}}(\boldsymbol{A}; \boldsymbol{x}) = \sup_{\boldsymbol{h} \neq \boldsymbol{0}} \frac{\|\boldsymbol{A}\boldsymbol{h}\|_2 / \|\boldsymbol{A}\boldsymbol{x}\|_2}{\|\boldsymbol{h}\|_2 / \|\boldsymbol{x}\|_2}$$

为线性作用 $\boldsymbol{x} \mapsto \boldsymbol{A}\boldsymbol{x}$ 在 $\boldsymbol{x}$ 处的**相对条件数**（relative condition number）。

这个上确界可以直接算出，并给出对任意扰动成立的相对误差界。

定理 7.5　相对条件数与相对误差界　在定义 7.4的条件下，

$$\kappa_{\mathrm{rel}}(\boldsymbol{A}; \boldsymbol{x}) = \frac{\|\boldsymbol{A}\|_2 \|\boldsymbol{x}\|_2}{\|\boldsymbol{A}\boldsymbol{x}\|_2},$$

并且对任意 $\boldsymbol{h} \in \mathbb{R}^n$，

$$\frac{\|\boldsymbol{A}\boldsymbol{h}\|_2}{\|\boldsymbol{A}\boldsymbol{x}\|_2} \le \kappa_{\mathrm{rel}}(\boldsymbol{A};\boldsymbol{x})\,\frac{\|\boldsymbol{h}\|_2}{\|\boldsymbol{x}\|_2}, \tag{7.1}$$

扰动沿最大右奇异方向 $\boldsymbol{h} = c\boldsymbol{v}_1$（$c \neq 0$）时等号成立。

证明 对 $\boldsymbol{h} \neq \boldsymbol{0}$，定义中的比值可以写成

$$\frac{\|\boldsymbol{x}\|_2}{\|\boldsymbol{A}\boldsymbol{x}\|_2} \cdot \frac{\|\boldsymbol{A}\boldsymbol{h}\|_2}{\|\boldsymbol{h}\|_2}.$$

第一个因子与 $\boldsymbol{h}$ 无关；由定理 7.1，第二个因子的上确界是 $\|\boldsymbol{A}\|_2 = \sigma_{\max}(\boldsymbol{A})$，并在 $\boldsymbol{h} = c\boldsymbol{v}_1$ 时取到。这就得到 κ_{rel} 的表达式和等号条件。不等式 (7.1)在 $\boldsymbol{h} \neq \boldsymbol{0}$ 时是上确界定义的改写，$\boldsymbol{h} = \boldsymbol{0}$ 时两端都为零。 ■

相对条件数描述的是：基点固定在 $\boldsymbol{x}$，扰动方向任意时，相对误差最多放大多少倍。回到示例 7.2：$\|\boldsymbol{A}\|_2 = 1$，在 $\boldsymbol{x} = \boldsymbol{e}_2$ 处 $\kappa_{\mathrm{rel}} = 1 \cdot 1/s = 1/s$，示例中的扰动 $\eta\boldsymbol{e}_1$ 恰沿最大右奇异方向，达到了这个值；在 $\boldsymbol{x} = \boldsymbol{e}_1$ 处 $\kappa_{\mathrm{rel}} = 1$。沿某一个具体方向实际观察到的比值可以更小，例如在 $\boldsymbol{x} = \boldsymbol{e}_2$ 处取 $\boldsymbol{h} = \eta\boldsymbol{e}_2$，输出相对误差为 $s\eta/s = \eta$，比值只有 1。

由表达式 $\kappa_{\mathrm{rel}}(\boldsymbol{A};\boldsymbol{x}) = \sigma_{\max}\|\boldsymbol{x}\|_2/\|\boldsymbol{A}\boldsymbol{x}\|_2$，可以用奇异方向辨认敏感与不敏感的输入。分子与 $\boldsymbol{x}$ 的方向无关，所以敏感程度完全由分母决定：$\boldsymbol{x}$ 沿 $\boldsymbol{v}_1$ 时 $\|\boldsymbol{A}\boldsymbol{x}\|_2 = \sigma_{\max}\|\boldsymbol{x}\|_2$，相对条件数取最小值 1；$\boldsymbol{x}$ 越靠近被压缩得厉害的右奇异方向，理想输出越短，同样的输出增量占的比例越大。

上面的两个上确界都取遍全部非零的有限扰动，而不是先让扰动趋于零。这样做可行，是因为线性作用的误差比与扰动的大小无关，只依赖方向；所以定理中的误差界对任意大小的扰动都成立。一般非线性映射 F 的输出增量 $F(\boldsymbol{z}+\boldsymbol{h}) - F(\boldsymbol{z})$ 不再与 $\boldsymbol{h}$ 成比例，误差比会随扰动半径变化。那时要先在半径为 δ 的扰动中取最坏值，再令 δ 缩小，用第 3.2节的极限定义局部条件数，并在可微条件下把它与微分的范数联系起来。这些在第 20章建立。本节只讨论线性作用，不用一般映射的定义代替这里的直接推导。

7.1.3 矩阵条件数与方向差异

相对条件数随基点变化：基点落在被压缩的方向上时，$\|\boldsymbol{A}\boldsymbol{x}\|_2$ 小，相对条件数大。若事先不知道输入落在哪里，就要对基点也取最坏值。对可逆方阵，这个最坏值只依赖矩阵本身。

定义 7.6　可逆矩阵的条件数　对同一向量范数诱导的矩阵范数，可逆方阵 $\boldsymbol{A}$ 的条件数（condition number）为

$$\kappa(\boldsymbol{A}) = \|\boldsymbol{A}\|\,\|\boldsymbol{A}^{-1}\|. \tag{7.2}$$

欧氏范数下记为 $\kappa_2(\boldsymbol{A})$。

下面的定理说明，这个数正是相对条件数对全部基点的最坏值，并由奇异值读出。

定理 7.7　条件数是相对条件数的最坏值　设 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$ 可逆，奇异值为 $\sigma_{\max} = \sigma_1 \geq \cdots \geq \sigma_n = \sigma_{\min} > 0$，对应的单位右奇异向量为 $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_n$。则

1. 对全部非零基点取最坏值，

$$\sup_{\boldsymbol{x}\neq\boldsymbol{0}} \kappa_{\mathrm{rel}}(\boldsymbol{A};\boldsymbol{x}) = \kappa_2(\boldsymbol{A}) = \frac{\sigma_{\max}(\boldsymbol{A})}{\sigma_{\min}(\boldsymbol{A})}, \tag{7.3}$$

   且上确界在 $\boldsymbol{x} = \boldsymbol{v}_n$ 处取到；

2. 对任意 $\boldsymbol{x} \neq \boldsymbol{0}$ 与任意 $\boldsymbol{h}$，

$$\frac{\|\boldsymbol{A}\boldsymbol{h}\|_2}{\|\boldsymbol{A}\boldsymbol{x}\|_2} \leq \kappa_2(\boldsymbol{A})\,\frac{\|\boldsymbol{h}\|_2}{\|\boldsymbol{x}\|_2},$$

   当 $\boldsymbol{x} = \boldsymbol{v}_n$、$\boldsymbol{h} = c\boldsymbol{v}_1$（$c \neq 0$）时等号成立；

3. 特别地，对可逆方程 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$（$\boldsymbol{b} \neq \boldsymbol{0}$），右端改为 $\boldsymbol{b} + \Delta\boldsymbol{b}$ 时，解的增量 $\Delta\boldsymbol{x}$ 对任意大小的 $\Delta\boldsymbol{b}$ 都满足

$$\frac{\|\Delta\boldsymbol{x}\|_2}{\|\boldsymbol{x}\|_2} \leq \kappa_2(\boldsymbol{A})\,\frac{\|\Delta\boldsymbol{b}\|_2}{\|\boldsymbol{b}\|_2}.$$

证明　先证第 1 条。把 $\boldsymbol{x}$ 按右奇异向量展开为 $\boldsymbol{x} = \sum_i c_i\boldsymbol{v}_i$，则

$$\|\boldsymbol{A}\boldsymbol{x}\|_2^2 = \sum_i \sigma_i^2 c_i^2 \geq \sigma_n^2 \sum_i c_i^2 = \sigma_n^2\|\boldsymbol{x}\|_2^2,$$

等号在 $\boldsymbol{x} = \boldsymbol{v}_n$ 时成立。由定理 7.5，

$$\kappa_{\mathrm{rel}}(\boldsymbol{A};\boldsymbol{x}) = \frac{\sigma_1\|\boldsymbol{x}\|_2}{\|\boldsymbol{A}\boldsymbol{x}\|_2} \leq \frac{\sigma_1}{\sigma_n},$$

在 $\boldsymbol{x} = \boldsymbol{v}_n$ 时取等号，所以上确界等于 σ_1/σ_n 且取到。又由第 5章，$\|\boldsymbol{A}\|_2 = \sigma_1$、$\|\boldsymbol{A}^{-1}\|_2 = 1/\sigma_n$，故 $\sigma_1/\sigma_n = \kappa_2(\boldsymbol{A})$。

第 2 条：$\boldsymbol{A}$ 可逆且 $\boldsymbol{x}\neq\boldsymbol{0}$，所以 $\boldsymbol{A}\boldsymbol{x}\neq\boldsymbol{0}$，可以使用式 (7.1)，再用第 1 条把 $\kappa_{\mathrm{rel}}(\boldsymbol{A};\boldsymbol{x})$ 放大为 $\kappa_2(\boldsymbol{A})$。$\boldsymbol{x}=\boldsymbol{v}_n$ 时第一步放大取等号；$\boldsymbol{h}=c\boldsymbol{v}_1$ 时式 (7.1)取等号。

第 3 条：由 $\boldsymbol{A}(\boldsymbol{x}+\Delta\boldsymbol{x})=\boldsymbol{b}+\Delta\boldsymbol{b}$ 减去 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$，得 $\Delta\boldsymbol{x}=\boldsymbol{A}^{-1}\Delta\boldsymbol{b}$。这是线性作用 $\boldsymbol{A}^{-1}$ 在基点 $\boldsymbol{b}$ 处对扰动 $\Delta\boldsymbol{b}$ 的输出增量，理想输出为 $\boldsymbol{A}^{-1}\boldsymbol{b}=\boldsymbol{x}\neq\boldsymbol{0}$。把第 2 条用于 $\boldsymbol{A}^{-1}$，并注意 $\boldsymbol{A}^{-1}$ 的奇异值是 $1/\sigma_n\geq\cdots\geq 1/\sigma_1$，所以 $\kappa_2(\boldsymbol{A}^{-1})=\sigma_1/\sigma_n=\kappa_2(\boldsymbol{A})$，即得结论。 ■

等号条件说明了矩阵条件数比较的是什么：基点取在最弱的右奇异方向 $\boldsymbol{v}_n$ 上，理想输出被压到最短；扰动取在最强的右奇异方向 $\boldsymbol{v}_1$ 上，输出增量被拉到最长。两者之比 $\sigma_{\max}/\sigma_{\min}$ 就是最强作用与最弱作用的差异。

证明中的欧氏范数并非必需：对任一向量范数及其诱导的矩阵范数，同样的论证给出 $\kappa_{\mathrm{rel}}(\boldsymbol{A};\boldsymbol{x})=\|\boldsymbol{A}\|\|\boldsymbol{x}\|/\|\boldsymbol{A}\boldsymbol{x}\|$，再令 $\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}$，由 $\boldsymbol{A}$ 可逆，$\boldsymbol{y}$ 取遍全部非零向量，

$$\begin{aligned}\sup_{\boldsymbol{x}\neq\boldsymbol{0}}\frac{\|\boldsymbol{A}\|\|\boldsymbol{x}\|}{\|\boldsymbol{A}\boldsymbol{x}\|}&=\|\boldsymbol{A}\|\sup_{\boldsymbol{y}\neq\boldsymbol{0}}\frac{\|\boldsymbol{A}^{-1}\boldsymbol{y}\|}{\|\boldsymbol{y}\|}\\&=\|\boldsymbol{A}\|\,\|\boldsymbol{A}^{-1}\|,\end{aligned}$$

所以定理的第 2、3 条在该范数下以 $\kappa(\boldsymbol{A})$ 代替 $\kappa_2(\boldsymbol{A})$ 仍然成立，只是不再有奇异值的表达式。

条件数总不小于 1，因为 $1=\|\boldsymbol{I}\|=\|\boldsymbol{A}\boldsymbol{A}^{-1}\|\leq\|\boldsymbol{A}\|\|\boldsymbol{A}^{-1}\|=\kappa(\boldsymbol{A})$。几何上，第 5章说明 $\boldsymbol{A}$ 把单位球映成以 σ_i 为半轴长的椭球，$\kappa_2(\boldsymbol{A})$ 就是最长半轴与最短半轴之比。正交矩阵把单位球映成单位球，奇异值全为 1，$\kappa_2=1$；$\sigma_{\max}$ 固定而 $\sigma_{\min}$ 趋于零时，椭球越来越扁，κ_2 越来越大。

条件数接近 1 时称问题良态，条件数很大时称问题病态。图 7.1把单位圆与误差圆盘分别送进两个矩阵：良态矩阵的像接近圆；病态矩阵的像被拉成细条，同样半径的误差圆盘反求后沿最弱方向被放大许多倍。

条件数看的是方向之间的差异，不是矩阵元素或奇异值的大小。比较 $\mathrm{diag}(1,s)$ 与 $s\boldsymbol{I}$（$0<s<1$）：前者的奇异值为 1 与 s，$\kappa_2=1/s$；后者的奇异值全为 s，$\kappa_2=1$。$s\boldsymbol{I}$ 把每个向量都缩小，数值整体更小，但它对所有方向一视同仁：对任意 $\boldsymbol{x}\neq\boldsymbol{0}$，$\kappa_{\mathrm{rel}}(s\boldsymbol{I};\boldsymbol{x})=s\|\boldsymbol{x}\|_2/(s\|\boldsymbol{x}\|_2)=1$，相对误差完全不被放大。$\mathrm{diag}(1,s)$ 只压缩第二个方向，示例 7.2中的放大正来自两个方向的这种差别。一般地，所有奇异值按同一比例缩放时条件数不变。

条件数也不描述反复作用的长期结果。下面两个矩阵的条件数相同，幂的变化趋势却相反。

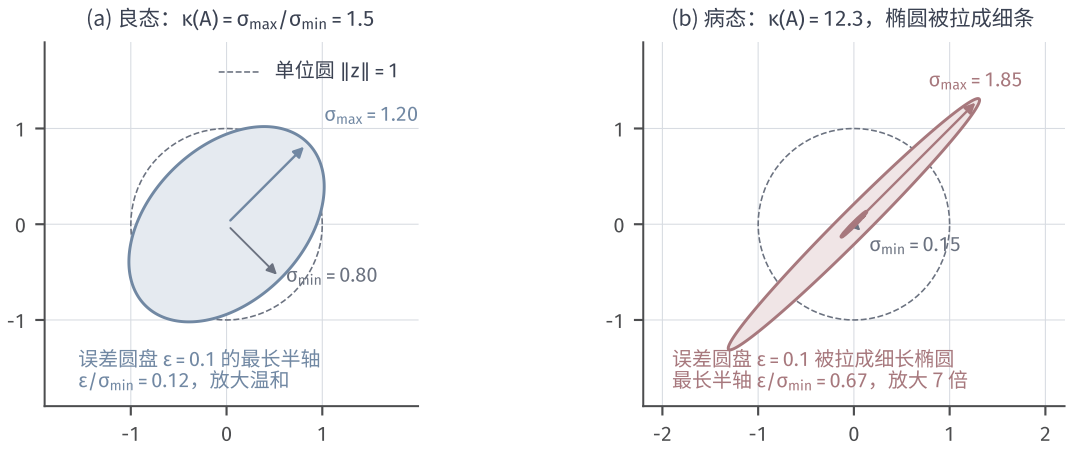


图 7.1 条件数对误差圆盘的放大。灰虚线为单位圆 $\|\boldsymbol{z}\| = 1$；左为良态 $\boldsymbol{A}_1 = [[1, 0.2], [0.2, 1]]$，奇异值 1.20 与 0.80，$\kappa_2 = 1.5$，像椭圆接近圆；右为病态 $\boldsymbol{A}_2 = [[1, 0.85], [0.85, 1]]$，奇异值 1.85 与 0.15，$\kappa_2 \approx 12.3$，像被拉成细条。半径 $\varepsilon = 0.1$ 的误差圆盘（红）最长半轴为 $\varepsilon/\sigma_{\min}$：良态为 0.125，病态约 0.67。

示例 7.8 条件数相同而幂的趋势相反 比较同阶的 $2\boldsymbol{I}$ 与 $\frac{1}{2}\boldsymbol{I}$。二者分别把每个方向放大 2 倍和缩小一半，奇异值全为 2 与全为 $\frac{1}{2}$，各方向之间没有差别，所以

$$\kappa_2(2\boldsymbol{I}) = \frac{2}{2} = 1, \qquad \kappa_2\big(\tfrac{1}{2}\boldsymbol{I}\big) = \frac{1/2}{1/2} = 1.$$

反复作用时二者却走向相反：$(2\boldsymbol{I})^k = 2^k\boldsymbol{I}$ 逐次增长，$(\frac{1}{2}\boldsymbol{I})^k = 2^{-k}\boldsymbol{I}$ 逐次衰减。条件数只比较最强与最弱方向之比，整体的放大或缩小在比值中被约掉了。

条件数衡量的是一次作用中相对误差的最坏放大，反复作用的长期行为要由谱半径判断（第 8.2节），二者不能互相代替。

最后说明本节结论的适用范围。本节始终固定矩阵 $\boldsymbol{A}$，只让输入向量带误差，条件数给出的是这种误差在一次线性作用中的最坏放大；它刻画问题本身的敏感性，不评价具体算法。

第 14.1节把输出改为方程的解，研究矩阵与右端同时带误差时的完整误差界，并区分数据误差与算法误差；第 20.2.2节再研究求逆和解映射对矩阵变化的一阶响应。下一节开始改变矩阵本身，分别检查特征值、奇异值和特征子空间。这些输出各有自己的敏感性度量，不能只凭 $\kappa_2(\boldsymbol{A})$ 判断它们是否敏感。

7.2 谱与奇异值的扰动

上一节固定矩阵，只让输入向量带误差。实际中矩阵本身也来自数据：协方差矩阵由有限样本估计，系数矩阵经过测量和舍入。设手中的矩阵与真实矩阵相差 $\boldsymbol{E}$，我们只知道误差预算 $\|\boldsymbol{E}\|_2 \le \varepsilon$。由手中矩阵算出的特征值、奇异值、秩和特征子空间，哪些结论对真实矩阵仍然可靠？

谱值的大小、矩阵是否接近秩亏、所选子空间的方向，是三种不同的输出，各自需要相应的界与条件。本节先为对称矩阵的每个特征值给出误差区间，并据此判断正负性；再把区间移到奇异值上，检查秩与可逆性；随后研究所选特征子空间的偏转，说明它由谱隙控制；最后说明一般方阵的特征值为什么需要额外的条件。

本节的界都是有限变化界，对任意大小的 $\boldsymbol{E}$ 成立，不需要微分。在可微条件下求所选特征值分支沿指定方向的一阶响应，留给第 20章（第 20.3.2节与第 20.3.3节）。

7.2.1 对称矩阵特征值的扰动

本小节取实对称矩阵 $\boldsymbol{S} \in \mathbb{R}^{d\times d}$ 与对称扰动 $\boldsymbol{E}$。二者的特征值都是实数，记 $\boldsymbol{S}$ 的特征值为 $\lambda_1(\boldsymbol{S}) \ge \cdots \ge \lambda_d(\boldsymbol{S})$，$\boldsymbol{S}+\boldsymbol{E}$ 的特征值也按降序记为 $\lambda_k(\boldsymbol{S}+\boldsymbol{E})$，再按同一次序逐个比较，把 $\lambda_k(\boldsymbol{S})$ 看作 $\lambda_k(\boldsymbol{S}+\boldsymbol{E})$ 的估计。目标是为每个特征值给出区间，并据此判断正负性和正定性。

图 7.2画出一个正定矩阵（图中记为 $\boldsymbol{A}$）受扰动前后的二次型椭圆：半轴长微变，主轴微转。半轴长对应特征值，主轴对应特征方向；本小节先处理前者，主轴的转动留到第 7.2.3节。

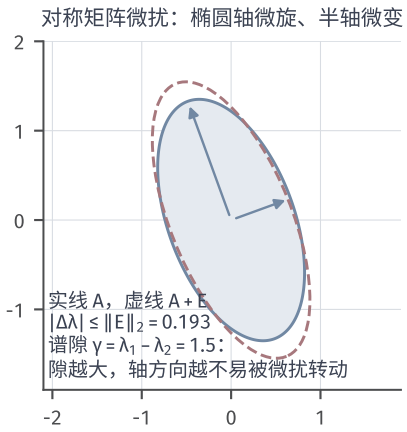


图 7.2　对称矩阵微扰的谱与方向。实线椭圆 $\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x}=1$ 对应 $\boldsymbol{A}$（特征值 2 与 0.5，主轴方向 20°），虚线对应 $\boldsymbol{A}+\boldsymbol{E}$（$\|\boldsymbol{E}\|_2 \approx 0.193$）：轴微旋、半轴微变。新特征值约 2.18 与 0.37，偏移 0.18、0.13 均小于 $\|\boldsymbol{E}\|_2$，符合 Weyl 界；未扰动的谱隙 $\delta=\lambda_1-\lambda_2=1.5$ 越大，特征方向越不易被微扰转动。

有序特征值的比较　扰动对同一方向上二次型的影响很容易估计：由 Cauchy–Schwarz 不等式，对任意 $\boldsymbol{x}$，

$$|\boldsymbol{x}^{\top}\boldsymbol{E}\boldsymbol{x}| \le \|\boldsymbol{x}\|_2\|\boldsymbol{E}\boldsymbol{x}\|_2 \le \|\boldsymbol{E}\|_2\|\boldsymbol{x}\|_2^2.$$

所以 $\boldsymbol{S}$ 与 $\boldsymbol{S}+\boldsymbol{E}$ 在同一个单位向量上的二次型值相差不超过 $\|\boldsymbol{E}\|_2$。难点在于把这个逐方向的比较传到第 k 个特征值上：两个矩阵的特征方向一般不同，不能直接拿同一个特征向量比较。

办法是用子空间刻画有序特征值。由谱分解，第 k 个特征值把前 k 个特征方向与后 $d-k+1$ 个特征方向分开，二次型在这两组方向张成的子空间上分别不小于、不大于 λ_k。

引理 7.9　特征子空间上的二次型界　设 $\boldsymbol{S}\in\mathbb{R}^{d\times d}$ 实对称，特征值为 $\lambda_1\ge\cdots\ge\lambda_d$，对应的标准正交特征向量为 $\boldsymbol{q}_1,\dots,\boldsymbol{q}_d$。对 $1\le k\le d$，记 $\mathcal{V}_k=\operatorname{span}\{\boldsymbol{q}_1,\dots,\boldsymbol{q}_k\}$，$\mathcal{W}_k=\operatorname{span}\{\boldsymbol{q}_k,\dots,\boldsymbol{q}_d\}$。则

$$\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}\ge\lambda_k\|\boldsymbol{x}\|_2^2\quad(\boldsymbol{x}\in\mathcal{V}_k),\qquad \boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}\le\lambda_k\|\boldsymbol{x}\|_2^2\quad(\boldsymbol{x}\in\mathcal{W}_k),$$

两式在 $\boldsymbol{x}=\boldsymbol{q}_k$ 时都取等号。

证明　对 $\boldsymbol{x}=\sum_{i\le k}c_i\boldsymbol{q}_i\in\mathcal{V}_k$，由二次型展开式 (4.5)，$\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}=\sum_{i\le k}\lambda_i c_i^2\ge\lambda_k\sum_{i\le k}c_i^2=\lambda_k\|\boldsymbol{x}\|_2^2$，因为 $i\le k$ 时 $\lambda_i\ge\lambda_k$。对 $\mathcal{W}_k$ 中的向量同理，只是 $i\ge k$ 时 $\lambda_i\le\lambda_k$。取 $\boldsymbol{x}=\boldsymbol{q}_k$ 时只有一项，两式都成为等式。 ■

两个子空间的维数分别是 k 与 $d-k+1$，和为 $d+1$，超过了空间的维数。由维数公式，任一 k 维子空间与任一 $d-k+1$ 维子空间的交至少是一维的：

$$\dim(\mathcal{V}\cap\mathcal{W})\ge\dim\mathcal{V}+\dim\mathcal{W}-d=1.$$

这样就能在两个矩阵各自的特征子空间中找到一个公共方向，在这个方向上比较二次型。

定理 7.10　Weyl 特征值扰动界　设 $\boldsymbol{S},\boldsymbol{E}\in\mathbb{R}^{d\times d}$ 实对称。对每个 $k=1,\dots,d$，按降序配对的特征值满足

$$|\lambda_k(\boldsymbol{S}+\boldsymbol{E})-\lambda_k(\boldsymbol{S})|\le\|\boldsymbol{E}\|_2. \tag{7.4}$$

证明 记 $\widetilde{\boldsymbol{S}} = \boldsymbol{S} + \boldsymbol{E}$，$c = \|\boldsymbol{E}\|_2$。取 $\boldsymbol{S}$ 前 k 个特征向量张成的 $\mathcal{V}_k$，以及 $\widetilde{\boldsymbol{S}}$ 第 k 个到第 d 个特征向量张成的 $\widetilde{\mathcal{W}}_k$。由维数公式，二者有公共的单位向量 $\boldsymbol{x}$。对 $\boldsymbol{S}$ 与 $\widetilde{\boldsymbol{S}}$ 分别使用引理 7.9，得

$$\lambda_k(\boldsymbol{S}) \le \boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}, \qquad \boldsymbol{x}^{\top}\widetilde{\boldsymbol{S}}\boldsymbol{x} \le \lambda_k(\widetilde{\boldsymbol{S}}).$$

又 $\boldsymbol{x}^{\top}\widetilde{\boldsymbol{S}}\boldsymbol{x} = \boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x} + \boldsymbol{x}^{\top}\boldsymbol{E}\boldsymbol{x} \ge \boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x} - c$，三式连起来，

$$\lambda_k(\widetilde{\boldsymbol{S}}) \ge \boldsymbol{x}^{\top}\widetilde{\boldsymbol{S}}\boldsymbol{x} \ge \boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x} - c \ge \lambda_k(\boldsymbol{S}) - c.$$

交换两个矩阵的角色，把 $\boldsymbol{S} = \widetilde{\boldsymbol{S}} + (-\boldsymbol{E})$ 看作 $\widetilde{\boldsymbol{S}}$ 的扰动，而 $\|-\boldsymbol{E}\|_2 = c$，同样得到 $\lambda_k(\boldsymbol{S}) \ge \lambda_k(\widetilde{\boldsymbol{S}}) - c$。两式合起来即为结论。 ■

证明只用了谱分解、维数公式和同一方向上二次型的比较，没有求任何二次型的最大值或最小值。它也不要求特征值彼此分开：重特征值时，$\boldsymbol{q}_k$ 可以在特征空间中任意选取，引理与证明都不受影响。

最小最大原理 证明中的论证还给出单个有序特征值的一种不依赖特征向量的刻画。把公共方向的论证用于任意子空间，就得到下面的结论。

定理 7.11 Courant–Fischer 设 $\boldsymbol{S} \in \mathbb{R}^{d\times d}$ 实对称，特征值为 $\lambda_1 \ge \cdots \ge \lambda_d$。对 $k = 1, \dots, d$，

$$\begin{aligned}\lambda_k &= \max_{\dim \mathcal{V} = k} \; \min_{\boldsymbol{x}\in\mathcal{V},\,\|\boldsymbol{x}\|_2 = 1} \boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x} \\ &= \min_{\dim \mathcal{W} = d-k+1} \; \max_{\boldsymbol{x}\in\mathcal{W},\,\|\boldsymbol{x}\|_2 = 1} \boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}.\end{aligned}$$

证明 先说明内层的最小值与最大值取得到。设 $\mathcal{V}$ 是 k 维子空间，$\boldsymbol{U} \in \mathbb{R}^{d\times k}$ 的列是它的标准正交基。$\boldsymbol{x} = \boldsymbol{U}\boldsymbol{y}$ 是 $\mathcal{V}$ 中的单位向量，当且仅当 $\boldsymbol{y}$ 是 $\mathbb{R}^k$ 中的单位向量，且 $\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x} = \boldsymbol{y}^{\top}\boldsymbol{M}\boldsymbol{y}$，其中 $\boldsymbol{M} = \boldsymbol{U}^{\top}\boldsymbol{S}\boldsymbol{U}$ 是 k 阶实对称矩阵。对 $\boldsymbol{M}$ 用谱定理与二次型展开式，单位向量上的 $\boldsymbol{y}^{\top}\boldsymbol{M}\boldsymbol{y}$ 是 $\boldsymbol{M}$ 的特征值的加权平均，最小值与最大值分别是 $\boldsymbol{M}$ 的最小、最大特征值，并在相应的特征向量处取到。

再证第一式。由引理 7.9，$\mathcal{V}_k$ 中单位向量的二次型不小于 λ_k，且在 $\boldsymbol{q}_k$ 处等于 λ_k，所以外层的最大值至少为 λ_k。反过来，任一 k 维子空间 $\mathcal{V}$ 与 $\mathcal{W}_k$ 有公共的单位向量 $\boldsymbol{x}$，它的二次型不超过 λ_k，所以 $\mathcal{V}$ 上的最小值不超过 λ_k。两方面合起来，外层最大值等于 λ_k，并在 $\mathcal{V}_k$ 处取到。

第二式交换两组特征向量的角色：$\mathcal{W}_k$ 上单位向量的二次型的最大值恰为 λ_k；任一 $d-k+1$ 维子空间 $\mathcal{W}$ 与 $\mathcal{V}_k$ 有公共的单位向量，其二次型不小于 λ_k，所以 $\mathcal{W}$ 上的最大值不小于 λ_k。 ■

这一定理称为**最小最大原理**（min-max principle）。它只涉及子空间与二次型，不要求先知道特征向量；Weyl 界也可以由它推出，只需对同一个子空间比较 $\boldsymbol{S}$ 与 $\boldsymbol{S}+\boldsymbol{E}$ 的二次型。$k=1$ 与 $k=d$ 时，内层只剩一个子空间，结论化为二次型在单位球面上的最大值与最小值；第 15章把 $\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}/\boldsymbol{x}^{\top}\boldsymbol{x}$ 称为 Rayleigh 商，并从选择最优方向的问题出发研究这两个极值。那里的迹极值汇总 k 个正交方向的贡献，刻画前 k 个特征值之和；最小最大原理刻画的是单个有序特征值。

谱值区间与正定性保证　由 Weyl 界，若 $\|\boldsymbol{E}\|_2 \le \varepsilon$，每个真实特征值都落在区间 $[\lambda_k(\boldsymbol{S})-\varepsilon, \lambda_k(\boldsymbol{S})+\varepsilon]$ 内。这个绝对误差界不要求特征值彼此分开，单重与重复特征值都适用。但它是绝对误差界：特征值本身接近零时，区间宽度 2ε 可能与特征值同量级，不能据此宣称相对误差也小。

区间立刻给出特征值符号的判断。若区间不含零，符号由区间确定；若区间含零，当前的误差预算不足以判断符号。例如 $\boldsymbol{S}=\operatorname{diag}(1,\varepsilon/2)$，$0<\varepsilon<1$：取 $\boldsymbol{E}=\boldsymbol{0}$ 时第二个特征值为正，取 $\boldsymbol{E}=-\varepsilon\boldsymbol{e}_2\boldsymbol{e}_2^{\top}$ 时它变为 $-\varepsilon/2$，两种扰动都满足预算。正定矩阵沿一条线段变化时，还可以得到对整条线段一致的下界。

定理 7.12　特征值的符号与正定性保持　设 $\boldsymbol{S},\boldsymbol{E}\in\mathbb{R}^{d\times d}$ 实对称，$\|\boldsymbol{E}\|_2\le\varepsilon$。

1. 若 $\lambda_k(\boldsymbol{S})>\varepsilon$，则 $\lambda_k(\boldsymbol{S}+\boldsymbol{E})>0$；若 $\lambda_k(\boldsymbol{S})<-\varepsilon$，则 $\lambda_k(\boldsymbol{S}+\boldsymbol{E})<0$。
2. 若 $\boldsymbol{S}$ 正定且 $\varepsilon<\lambda_{\min}(\boldsymbol{S})$，则对一切 $t\in[0,1]$，

$$\lambda_{\min}(\boldsymbol{S}+t\boldsymbol{E})\ge\lambda_{\min}(\boldsymbol{S})-\varepsilon>0,$$

从而线段 $\{\boldsymbol{S}+t\boldsymbol{E}:0\le t\le 1\}$ 上的矩阵都正定。

证明　第 1 条：由定理 7.10，$\lambda_k(\boldsymbol{S}+\boldsymbol{E})\ge\lambda_k(\boldsymbol{S})-\varepsilon>0$；负号情形同理，$\lambda_k(\boldsymbol{S}+\boldsymbol{E})\le\lambda_k(\boldsymbol{S})+\varepsilon<0$。第 2 条：对 $t\in[0,1]$，$t\boldsymbol{E}$ 对称且 $\|t\boldsymbol{E}\|_2=t\|\boldsymbol{E}\|_2\le\varepsilon$。对最小特征值 λ_d 应用定理 7.10，得 $\lambda_{\min}(\boldsymbol{S}+t\boldsymbol{E})\ge\lambda_{\min}(\boldsymbol{S})-\varepsilon>0$。实对称矩阵的特征值全为正时，由二次型展开式 (4.5)，它是正定的。 ■

第 2 条的下界 $\lambda_{\min}(\boldsymbol{S})-\varepsilon$ 与 t 无关。后文对正定矩阵求逆、开方或取对数时，常需确认整条线段都留在这些运算的定义域内，并且离定义域边界有一致的距离，例如第 20.2.4节估计对数行列式的变化；这个下界正好提供这一保证。

最后用一个例子检查界的精确程度，并看到有限变化界与可微性是两回事。

示例 7.13　重根处的最大特征值　取 $\boldsymbol{S}(t)=\operatorname{diag}(t,-t)$，$t\in\mathbb{R}$，从重根 $\boldsymbol{S}(0)=\boldsymbol{0}$ 出发看最大特征值怎样移动。$\boldsymbol{S}(0)$ 的特征值 0 是二重根；$t\neq 0$ 时两个特征值 $\pm t$ 分开，排序后的最大特征值为 $|t|$。

它相对于 $\boldsymbol{S}(0)$ 的变化是 $|t|$，恰好等于 $\|\boldsymbol{S}(t)-\boldsymbol{S}(0)\|_2=|t|$，所以界 (7.4)在这里取等号，不能再改进；同时也说明重根并不妨碍有限的绝对误差界。但有界的变化不等于光滑的变化：$|t|$ 在 $t=0$ 处左导数为 -1、右导数为 1，排序后的最大特征值在重根处没有双侧导数。原因是 t 变号时，最大特征值从 t 这一支换到 $-t$ 那一支。

第 20.1.1节再用这个例子区分有限敏感性与可微性；第 20.3.2节在特征值简单的条件下，另行研究所选分支的一阶响应。

7.2.2　奇异值的扰动与秩判断

秩、可逆性与最佳低秩逼近的误差都由奇异值决定。本小节先把上一小节的特征值区间移到奇异值上，再据此判断哪些关于秩的结论在误差预算下仍然可靠。

奇异值的误差区间　长方矩阵没有特征值，不能直接使用 Weyl 界。办法是把它放进一个对称矩阵，使后者的特征值恰好包含原矩阵的奇异值。对 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$，记 $p=\min(m,n)$，奇异值为 $\sigma_1(\boldsymbol{A})\geq\cdots\geq\sigma_p(\boldsymbol{A})\geq 0$，定义 $(m+n)$ 阶对称增广矩阵

$$\boldsymbol{H}(\boldsymbol{A})=\begin{bmatrix}\boldsymbol{0} & \boldsymbol{A}\\ \boldsymbol{A}^{\top} & \boldsymbol{0}\end{bmatrix},$$

引理 7.14　对称增广矩阵的谱　$\boldsymbol{H}(\boldsymbol{A})$ 的特征值为 $\pm\sigma_1(\boldsymbol{A})$、…、$\pm\sigma_p(\boldsymbol{A})$，以及 $|m-n|$ 个零。特别地，按降序排列时它的前 p 个特征值依次为 $\sigma_1(\boldsymbol{A}),\dots,\sigma_p(\boldsymbol{A})$；并且 $\|\boldsymbol{H}(\boldsymbol{A})\|_2=\|\boldsymbol{A}\|_2$。

证明　由定理 5.1，取完整的 SVD $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$，列向量为 $\boldsymbol{u}_1,\dots,\boldsymbol{u}_m$ 与 $\boldsymbol{v}_1,\dots,\boldsymbol{v}_n$。对 $i\le p$，有 $\boldsymbol{A}\boldsymbol{v}_i=\sigma_i\boldsymbol{u}_i$ 与 $\boldsymbol{A}^{\top}\boldsymbol{u}_i=\boldsymbol{V}\boldsymbol{\Sigma}^{\top}\boldsymbol{e}_i=\sigma_i\boldsymbol{v}_i$。令

$$\boldsymbol{w}_i^{\pm}=\frac{1}{\sqrt{2}}\begin{bmatrix}\boldsymbol{u}_i\\ \pm\boldsymbol{v}_i\end{bmatrix},$$

用 $(\boldsymbol{a};\boldsymbol{b})$ 表示把 $\boldsymbol{a}$、$\boldsymbol{b}$ 上下拼接成的列向量，则

$$\boldsymbol{H}(\boldsymbol{A})\boldsymbol{w}_i^{\pm}=\tfrac{1}{\sqrt{2}}(\pm\boldsymbol{A}\boldsymbol{v}_i;\boldsymbol{A}^{\top}\boldsymbol{u}_i)=\tfrac{1}{\sqrt{2}}(\pm\sigma_i\boldsymbol{u}_i;\sigma_i\boldsymbol{v}_i)=\pm\sigma_i\boldsymbol{w}_i^{\pm}.$$

若 $m>n$，对 $j>n$，$\boldsymbol{\Sigma}^{\top}$ 的第 j 列为零，故 $\boldsymbol{A}^{\top}\boldsymbol{u}_j=\boldsymbol{0}$，向量 $(\boldsymbol{u}_j;\boldsymbol{0})$ 是特征值 0 的特征向量；若 $n>m$，对 $j>m$ 有 $\boldsymbol{A}\boldsymbol{v}_j=\boldsymbol{0}$，向量 $(\boldsymbol{0};\boldsymbol{v}_j)$ 是特征值 0 的特征向量。这 $2p+|m-n|=m+n$ 个向量两两正交且长度为 1：由 $\boldsymbol{u}_i$、$\boldsymbol{v}_i$ 各自标准正交，$\boldsymbol{w}_i^{\pm}$ 与 $\boldsymbol{w}_j^{\pm}$ 的内积为 $\frac{1}{2}(\boldsymbol{u}_i^{\top}\boldsymbol{u}_j\pm\boldsymbol{v}_i^{\top}\boldsymbol{v}_j)$，两者符号相同时取正号、相反时取负号，所以 $i\ne j$ 时为零，$i=j$ 而符号相反时为 $\frac{1}{2}(1-1)=0$，符号相同时为 1；补充的向量 $(\boldsymbol{u}_j;\boldsymbol{0})$ 或 $(\boldsymbol{0};\boldsymbol{v}_j)$ 只含 $j>p$ 的分量，与所有 $\boldsymbol{w}_i^{\pm}$ 及彼此都正交。所以它们构成 $\boldsymbol{H}(\boldsymbol{A})$ 的标准正交特征基，列出了全部特征值（计重数）。$\sigma_i\ge 0\ge-\sigma_j$，所以降序排列时前 p 个是 $\sigma_1,\dots,\sigma_p$。

最后，对 $\boldsymbol{z}=(\boldsymbol{y};\boldsymbol{x})$，$\boldsymbol{H}(\boldsymbol{A})\boldsymbol{z}=(\boldsymbol{A}\boldsymbol{x};\boldsymbol{A}^{\top}\boldsymbol{y})$。$\boldsymbol{A}^{\top}$ 与 $\boldsymbol{A}$ 有相同的非零奇异值，所以 $\|\boldsymbol{A}^{\top}\|_2=\|\boldsymbol{A}\|_2$，于是

$$\begin{aligned}\|\boldsymbol{H}(\boldsymbol{A})\boldsymbol{z}\|_2^2&=\|\boldsymbol{A}\boldsymbol{x}\|_2^2+\|\boldsymbol{A}^{\top}\boldsymbol{y}\|_2^2\\&\le\|\boldsymbol{A}\|_2^2\big(\|\boldsymbol{x}\|_2^2+\|\boldsymbol{y}\|_2^2\big)=\|\boldsymbol{A}\|_2^2\|\boldsymbol{z}\|_2^2,\end{aligned}$$

而 $\boldsymbol{z}=\boldsymbol{w}_1^{+}$ 时 $\|\boldsymbol{H}(\boldsymbol{A})\boldsymbol{z}\|_2=\sigma_1=\|\boldsymbol{A}\|_2$，故 $\|\boldsymbol{H}(\boldsymbol{A})\|_2=\|\boldsymbol{A}\|_2$。 ■

定理 7.15　奇异值的 Weyl 界　设 $\boldsymbol{A},\boldsymbol{E}\in\mathbb{R}^{m\times n}$，$p=\min(m,n)$。对 $i=1,\dots,p$，

$$|\sigma_i(\boldsymbol{A}+\boldsymbol{E})-\sigma_i(\boldsymbol{A})|\le\|\boldsymbol{E}\|_2. \tag{7.5}$$

证明　增广是线性的：$\boldsymbol{H}(\boldsymbol{A}+\boldsymbol{E})=\boldsymbol{H}(\boldsymbol{A})+\boldsymbol{H}(\boldsymbol{E})$，三者都实对称。对 $\boldsymbol{H}(\boldsymbol{A})$ 与扰动 $\boldsymbol{H}(\boldsymbol{E})$ 应用定理 7.10，第 i 个特征值的变化不超过 $\|\boldsymbol{H}(\boldsymbol{E})\|_2$。由引理 7.14，$i\le p$ 时第 i 个特征值就是第 i 个奇异值，且 $\|\boldsymbol{H}(\boldsymbol{E})\|_2=\|\boldsymbol{E}\|_2$。 ■

奇异值非负，所以在误差预算 $\|\boldsymbol{E}\|_2\le\varepsilon$ 下，真实的第 i 个奇异值落在非负区间 $[\max(0,\sigma_i(\boldsymbol{A})-\varepsilon),\ \sigma_i(\boldsymbol{A})+\varepsilon]$ 内。

最佳低秩逼近的误差也随之受控。第 15章将证明（定理 15.11），对 $0 \le k < p$，秩不超过 k 的矩阵中，与 $\boldsymbol{A}$ 的最小谱范数距离为 $\sigma_{k+1}(\boldsymbol{A})$。把定理 7.15用于 $i = k+1$，扰动前后这个最优误差之差不超过 ε。要注意，这只说明最优误差的数值稳定；取得最优误差的低秩矩阵及其所用的奇异方向是否同样稳定，是另一个问题，留到下一小节。

秩保证与可逆性的边界　奇异值区间不含零，就能保证相应的奇异值为正，从而给出秩的下界。

定理 7.16　由奇异值保证秩　设 $\boldsymbol{A}, \boldsymbol{E} \in \mathbb{R}^{m\times n}$，$\|\boldsymbol{E}\|_2 \le \varepsilon$，$1 \le k \le \min(m,n)$。若 $\sigma_k(\boldsymbol{A}) > \varepsilon$，则 $\operatorname{rank}(\boldsymbol{A}+\boldsymbol{E}) \ge k$。特别地，$m \ge n$ 且 $\sigma_n(\boldsymbol{A}) > \varepsilon$ 时，$\boldsymbol{A}+\boldsymbol{E}$ 满列秩。

证明　由定理 7.15，$\sigma_k(\boldsymbol{A}+\boldsymbol{E}) \ge \sigma_k(\boldsymbol{A}) - \varepsilon > 0$，而奇异值降序排列，所以 $\boldsymbol{A}+\boldsymbol{E}$ 至少有 k 个正奇异值。由定理 5.1，正奇异值的个数等于秩。 ■

反方向的结论不成立：$\sigma_k(\boldsymbol{A}) \le \varepsilon$ 只表示区间 $[\max(0, \sigma_k(\boldsymbol{A})-\varepsilon), \sigma_k(\boldsymbol{A})+\varepsilon]$ 包含零，无法排除真实矩阵的第 k 个奇异值为零，但也不能由此断言真实矩阵秩亏。

这里要区分两种秩。精确秩对扰动不连续：$\operatorname{diag}(1,0) + t\boldsymbol{e}_2\boldsymbol{e}_2^{\top}$ 对每个 $t \ne 0$ 都可逆，秩为 2，$t = 0$ 时秩突然降为 1，无论 $|t|$ 多小。所以对带误差的矩阵，追问精确秩没有意义；可靠的是给定误差预算下的有效秩，即定理保证的下界“大于 ε 的奇异值个数”。本小节只给出由误差预算能够保证的结论；实际计算中怎样选取阈值、把大于阈值的奇异值个数作为数值秩，在第 14.1.4节结合求解任务讨论。

对可逆方阵，同样的想法回答：最小要多大的扰动，才能使它变成奇异矩阵？

定理 7.17　到奇异矩阵的距离　设 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$ 可逆，奇异值为 $\sigma_1 \ge \cdots \ge \sigma_n > 0$，$\boldsymbol{u}_n$、$\boldsymbol{v}_n$ 是与 σ_n 对应的单位左、右奇异向量。则

$$\min\{\|\boldsymbol{E}\|_2 : \boldsymbol{A}+\boldsymbol{E} \text{ 奇异}\} = \sigma_n(\boldsymbol{A}),$$

最小值在 $\boldsymbol{E}_* = -\sigma_n \boldsymbol{u}_n \boldsymbol{v}_n^{\top}$ 处取到。相对于 $\|\boldsymbol{A}\|_2$，这个距离为

$$\frac{\sigma_n(\boldsymbol{A})}{\|\boldsymbol{A}\|_2} = \frac{1}{\kappa_2(\boldsymbol{A})}.$$

证明　分两步证明：较小的扰动保持可逆，而 $\boldsymbol{E}_*$ 恰好使矩阵奇异。

下界：设 $\|\boldsymbol{E}\|_2 < \sigma_n$。对任意 $\boldsymbol{x} \neq \boldsymbol{0}$，由定理 7.7证明中的估计 $\|\boldsymbol{A}\boldsymbol{x}\|_2 \geq \sigma_n\|\boldsymbol{x}\|_2$，

$$\begin{aligned}\|(\boldsymbol{A}+\boldsymbol{E})\boldsymbol{x}\|_2 &\geq \|\boldsymbol{A}\boldsymbol{x}\|_2 - \|\boldsymbol{E}\boldsymbol{x}\|_2 \\ &\geq (\sigma_n - \|\boldsymbol{E}\|_2)\|\boldsymbol{x}\|_2 > 0,\end{aligned}$$

所以 $\boldsymbol{A}+\boldsymbol{E}$ 的零空间只含零向量，它可逆。可达：对任意 $\boldsymbol{x}$，$\|\boldsymbol{u}_n\boldsymbol{v}_n^{\mathsf{T}}\boldsymbol{x}\|_2 = |\boldsymbol{v}_n^{\mathsf{T}}\boldsymbol{x}| \leq \|\boldsymbol{x}\|_2$，且 $\boldsymbol{x} = \boldsymbol{v}_n$ 时取等号，故 $\|\boldsymbol{E}_*\|_2 = \sigma_n$；又 $(\boldsymbol{A}+\boldsymbol{E}_*)\boldsymbol{v}_n = \sigma_n\boldsymbol{u}_n - \sigma_n\boldsymbol{u}_n = \boldsymbol{0}$，所以 $\boldsymbol{A}+\boldsymbol{E}_*$ 奇异。相对距离由 $\|\boldsymbol{A}\|_2 = \sigma_1$ 与 $\kappa_2(\boldsymbol{A}) = \sigma_1/\sigma_n$ 得到。 ■

n 阶方阵奇异，当且仅当它的秩不超过 $n-1$，所以这个定理也是第 15章最佳低秩逼近在 $k = n-1$ 时的特例；这里的直接证明只用到最小奇异值的下界。这为上一节的矩阵条件数提供了另一种解释：$\kappa_2(\boldsymbol{A})$ 越大，按相对尺度计，$\boldsymbol{A}$ 离奇异矩阵越近。这个结论的条件是允许任意的谱范数扰动；若扰动必须保持某种结构，例如对称或稀疏，可选的扰动变少，本定理只给出距离的下界，相应的距离需要另行分析。还要注意，扰动超过 σ_n 并不意味着每个这样的扰动都使矩阵奇异，例如 $\boldsymbol{E} = \boldsymbol{A}$ 的范数为 $\sigma_1 \geq \sigma_n$，而 $\boldsymbol{A}+\boldsymbol{E} = 2\boldsymbol{A}$ 仍然可逆。

示例 7.18　对角矩阵的可逆性边界　回到上一节的 $\boldsymbol{A} = \operatorname{diag}(1, s)$，$0 < s < 1$。它的奇异值为 1 与 s，$\kappa_2(\boldsymbol{A}) = 1/s$。由定理 7.17，误差预算 $\varepsilon < s$ 时可以保证 $\boldsymbol{A}+\boldsymbol{E}$ 可逆。这个门槛不能再放宽：$\boldsymbol{E} = -s\boldsymbol{e}_2\boldsymbol{e}_2^{\mathsf{T}}$ 的范数恰为 s，它把第二个对角元抵消掉，使 $\boldsymbol{A}$ 变成奇异的 $\operatorname{diag}(1, 0)$。按相对尺度，这个距离是 $s/1 = 1/\kappa_2(\boldsymbol{A})$；$s$ 越小，条件数越大，$\boldsymbol{A}$ 离奇异矩阵也越近。

在这个例子中，s 很小时矩阵离奇异很近，但它的第一奇异方向 $\boldsymbol{e}_1$ 并不因此变得不稳定。下一小节将说明，保留第一奇异方向的稳定性由截断处的间隙 $\sigma_1 - \sigma_2 = 1 - s$ 决定，而可逆性的边界由最小奇异值 s 决定，二者不能互相替代。

7.2.3　特征子空间的扰动

即使特征值的绝对误差很小，按这些特征值选出的方向也可能变化很大。本小节研究：在给定的误差预算下，原来选出的特征子空间能偏转多少。先建立一种不依赖基的选择的子空间距离，再检查目标特征值组与其余特征值之间的间隔。

子空间的距离 比较特征向量时，比较对象应是子空间本身。特征向量可以变号；特征值重复时，特征空间内部还可以任意换标准正交基，这些都不改变子空间，所以单个基向量的变化不能当作子空间的误差。图 7.3从两条过原点的直线看起：两直线的夹角与方向向量的选取无关；把一条直线的单位方向向量投影到另一条上，投影不掉的部分长度为 $\sin\theta$。

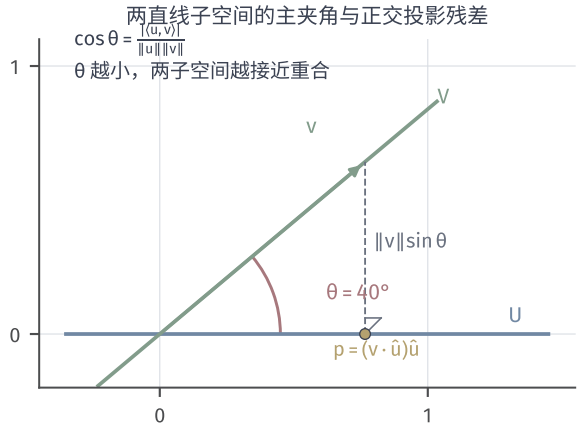


图 7.3 两条直线子空间的主夹角。蓝线为 $\boldsymbol{U}$、绿线为 $\boldsymbol{V}$，红弧为主夹角 $\theta = 40°$；黄点 $\boldsymbol{p}$ 是 $\boldsymbol{v}$ 在 $\boldsymbol{U}$ 上的正交投影，灰虚线为投影垂线。$\cos 40° \approx 0.766$、$\sin 40° \approx 0.643$，残差长度 $\|\boldsymbol{v}\|\sin\theta$ 即投影不掉的分量。

对一维子空间，若 $\boldsymbol{q}, \tilde{\boldsymbol{q}}$ 是单位方向向量，则 $|\boldsymbol{q}^{\top}\tilde{\boldsymbol{q}}| = \cos\theta$。高维子空间之间有多个夹角，由交叉内积矩阵的奇异值给出。

定义 7.19 主夹角 设 $\boldsymbol{Q}, \tilde{\boldsymbol{Q}} \in \mathbb{R}^{d\times r}$ 列标准正交，分别张成 r 维子空间。交叉矩阵 $\boldsymbol{Q}^{\top}\tilde{\boldsymbol{Q}}$ 的奇异值记为 $\cos\theta_1 \geq \cdots \geq \cos\theta_r$，$0 \leq \theta_1 \leq \cdots \leq \theta_r \leq \pi/2$，这些 θ_i 称为两个子空间的**主夹角**（principal angles）。

这些奇异值都在 $[0,1]$ 内，因为 $\|\boldsymbol{Q}^{\top}\tilde{\boldsymbol{Q}}\|_2 \leq \|\boldsymbol{Q}\|_2\|\tilde{\boldsymbol{Q}}\|_2 = 1$，所以 θ_i 有定义。换基相当于把 $\boldsymbol{Q}$、$\tilde{\boldsymbol{Q}}$ 分别右乘 r 阶正交矩阵 $\boldsymbol{R}$、$\tilde{\boldsymbol{R}}$，交叉矩阵变为 $\boldsymbol{R}^{\top}(\boldsymbol{Q}^{\top}\tilde{\boldsymbol{Q}})\tilde{\boldsymbol{R}}$，奇异值不变，所以主夹角只依赖两个子空间。最大主夹角 θ_r 记为 $\theta_{\max}$。

主夹角的正弦度量一个子空间伸出另一个子空间的部分，它们也可以直接读出，并与正交投影之差联系起来。设 $\tilde{\boldsymbol{Q}}_{\perp} \in \mathbb{R}^{d\times(d-r)}$ 的列是 $\tilde{\boldsymbol{Q}}$ 列空间正交补的标准正交基，记

$$\boldsymbol{C} = \tilde{\boldsymbol{Q}}^{\top}\boldsymbol{Q}, \qquad \boldsymbol{X} = \tilde{\boldsymbol{Q}}_{\perp}^{\top}\boldsymbol{Q},$$

再记两个子空间上的正交投影为 $\boldsymbol{P} = \boldsymbol{Q}\boldsymbol{Q}^{\top}$、$\tilde{\boldsymbol{P}} = \tilde{\boldsymbol{Q}}\tilde{\boldsymbol{Q}}^{\top}$，它们与基的选取无关。

定理 7.20　主夹角的正弦与投影之差　在上述记号下，$\boldsymbol{X}^{\top}\boldsymbol{X} = \boldsymbol{I} - \boldsymbol{C}^{\top}\boldsymbol{C}$，其特征值为 $\sin^2\theta_1, \dots, \sin^2\theta_r$，并且

$$\frac{1}{2}\|\boldsymbol{P} - \widetilde{\boldsymbol{P}}\|_{\mathrm{F}}^2 = \sum_{i=1}^{r} \sin^2\theta_i = \|\boldsymbol{X}\|_{\mathrm{F}}^2.$$

证明　$[\widetilde{\boldsymbol{Q}}, \widetilde{\boldsymbol{Q}}_{\perp}]$ 是正交矩阵，所以对任意 $\boldsymbol{a} \in \mathbb{R}^r$，把 $\boldsymbol{Q}\boldsymbol{a}$ 分解到 $\widetilde{\boldsymbol{Q}}$ 的列空间与其正交补，由勾股定理，

$$\|\boldsymbol{C}\boldsymbol{a}\|_2^2 + \|\boldsymbol{X}\boldsymbol{a}\|_2^2 = \|\boldsymbol{Q}\boldsymbol{a}\|_2^2 = \|\boldsymbol{a}\|_2^2.$$

即对称矩阵 $\boldsymbol{X}^{\top}\boldsymbol{X}$ 与 $\boldsymbol{I} - \boldsymbol{C}^{\top}\boldsymbol{C}$ 的二次型处处相等。对称矩阵由其二次型唯一确定（用 $\boldsymbol{a}+\boldsymbol{b}$ 与 $\boldsymbol{a}-\boldsymbol{b}$ 的二次型之差可以读出 $\boldsymbol{a}^{\top}\boldsymbol{M}\boldsymbol{b}$），所以 $\boldsymbol{X}^{\top}\boldsymbol{X} = \boldsymbol{I} - \boldsymbol{C}^{\top}\boldsymbol{C}$。$\boldsymbol{C}$ 是交叉矩阵 $\boldsymbol{Q}^{\top}\widetilde{\boldsymbol{Q}}$ 的转置，$\boldsymbol{C}^{\top}\boldsymbol{C}$ 的特征值是 $\cos^2\theta_i$，所以 $\boldsymbol{X}^{\top}\boldsymbol{X}$ 的特征值是 $1 - \cos^2\theta_i = \sin^2\theta_i$，且 $\|\boldsymbol{X}\|_{\mathrm{F}}^2 = \operatorname{tr}(\boldsymbol{X}^{\top}\boldsymbol{X}) = \sum_i \sin^2\theta_i$。

再算投影之差。$\boldsymbol{P}$、$\widetilde{\boldsymbol{P}}$ 对称且 $\boldsymbol{P}^2 = \boldsymbol{P}$、$\widetilde{\boldsymbol{P}}^2 = \widetilde{\boldsymbol{P}}$，$\operatorname{tr}\boldsymbol{P} = \operatorname{tr}(\boldsymbol{Q}^{\top}\boldsymbol{Q}) = r$，同样 $\operatorname{tr}\widetilde{\boldsymbol{P}} = r$。于是

$$\begin{aligned}\|\boldsymbol{P} - \widetilde{\boldsymbol{P}}\|_{\mathrm{F}}^2 &= \operatorname{tr}\big((\boldsymbol{P} - \widetilde{\boldsymbol{P}})^2\big) \\ &= \operatorname{tr}\boldsymbol{P} - 2\operatorname{tr}(\boldsymbol{P}\widetilde{\boldsymbol{P}}) + \operatorname{tr}\widetilde{\boldsymbol{P}} \\ &= 2r - 2\operatorname{tr}(\boldsymbol{P}\widetilde{\boldsymbol{P}}).\end{aligned}$$

由迹的循环性，$\operatorname{tr}(\boldsymbol{P}\widetilde{\boldsymbol{P}}) = \operatorname{tr}(\widetilde{\boldsymbol{Q}}^{\top}\boldsymbol{Q}\boldsymbol{Q}^{\top}\widetilde{\boldsymbol{Q}}) = \|\boldsymbol{Q}^{\top}\widetilde{\boldsymbol{Q}}\|_{\mathrm{F}}^2 = \sum_i \cos^2\theta_i$，代入得 $\|\boldsymbol{P} - \widetilde{\boldsymbol{P}}\|_{\mathrm{F}}^2 = 2\sum_i(1 - \cos^2\theta_i) = 2\sum_i \sin^2\theta_i$。 ■

Frobenius 范数汇总了所有主夹角，反映整体偏转。只关心最坏的那个方向时，用谱范数，它恰好读出最大主夹角。

定理 7.21　投影之差的谱范数　在定理 7.20的记号下，

$$\|\boldsymbol{P} - \widetilde{\boldsymbol{P}}\|_2 = \|\boldsymbol{X}\|_2 = \sin\theta_{\max}.$$

证明　由定理 7.20，$\boldsymbol{X}^{\top}\boldsymbol{X}$ 的最大特征值是 $\sin^2\theta_{\max}$，所以 $\|\boldsymbol{X}\|_2 = \sin\theta_{\max}$。

再设 $\boldsymbol{Q}_{\perp} \in \mathbb{R}^{d\times(d-r)}$ 的列是 $\boldsymbol{Q}$ 列空间正交补的标准正交基，于是 $\boldsymbol{I} - \boldsymbol{P} = \boldsymbol{Q}_{\perp}\boldsymbol{Q}_{\perp}^{\top}$、$\boldsymbol{I} - \widetilde{\boldsymbol{P}} = \widetilde{\boldsymbol{Q}}_{\perp}\widetilde{\boldsymbol{Q}}_{\perp}^{\top}$。先说明两个算子范数。列标准正交

的矩阵保持长度，行标准正交的矩阵不增加长度，并在其行空间上保持长度，所以

$$\|(\boldsymbol{I}-\widetilde{\boldsymbol{P}})\boldsymbol{P}\|_2 = \|\widetilde{\boldsymbol{Q}}_\perp(\widetilde{\boldsymbol{Q}}_\perp^\top \boldsymbol{Q})\boldsymbol{Q}^\top\|_2 = \|\boldsymbol{X}\|_2.$$

同理 $\|(\boldsymbol{I}-\boldsymbol{P})\widetilde{\boldsymbol{P}}\|_2 = \|\boldsymbol{Q}_\perp^\top\widetilde{\boldsymbol{Q}}\|_2$。把定理 7.20中两个子空间的角色交换，交叉矩阵变为 $\widetilde{\boldsymbol{Q}}^\top\boldsymbol{Q}$，它与原交叉矩阵互为转置，奇异值相同，所以 $\boldsymbol{Q}_\perp^\top\widetilde{\boldsymbol{Q}}$ 的最大奇异值同样是 $\sin\theta_{\max}$。

上界：直接展开可验证

$$\boldsymbol{P}-\widetilde{\boldsymbol{P}} = \boldsymbol{P}(\boldsymbol{I}-\widetilde{\boldsymbol{P}}) - (\boldsymbol{I}-\boldsymbol{P})\widetilde{\boldsymbol{P}}.$$

对任意 $\boldsymbol{z}$，右端第一项落在 $\boldsymbol{Q}$ 的列空间中，第二项落在其正交补中，由勾股定理，

$$\begin{aligned}\|(\boldsymbol{P}-\widetilde{\boldsymbol{P}})\boldsymbol{z}\|_2^2 &= \|\boldsymbol{P}(\boldsymbol{I}-\widetilde{\boldsymbol{P}})\boldsymbol{z}\|_2^2 + \|(\boldsymbol{I}-\boldsymbol{P})\widetilde{\boldsymbol{P}}\boldsymbol{z}\|_2^2 \\ &\le \sin^2\theta_{\max}\big(\|(\boldsymbol{I}-\widetilde{\boldsymbol{P}})\boldsymbol{z}\|_2^2 + \|\widetilde{\boldsymbol{P}}\boldsymbol{z}\|_2^2\big) \\ &= \sin^2\theta_{\max}\|\boldsymbol{z}\|_2^2.\end{aligned}$$

这里第二行用到 $\boldsymbol{P}(\boldsymbol{I}-\widetilde{\boldsymbol{P}}) = \big((\boldsymbol{I}-\widetilde{\boldsymbol{P}})\boldsymbol{P}\big)^\top$，转置不改变谱范数，并对两项分别使用上面的范数等式；第三行再用勾股定理。

下界：取单位向量 $\boldsymbol{a}\in\mathbb{R}^r$ 使 $\|\boldsymbol{X}\boldsymbol{a}\|_2 = \|\boldsymbol{X}\|_2$（取 $\boldsymbol{X}$ 的第一右奇异向量），令 $\boldsymbol{z} = \boldsymbol{Q}\boldsymbol{a}$，则 $\|\boldsymbol{z}\|_2 = 1$，$\boldsymbol{P}\boldsymbol{z} = \boldsymbol{z}$，

$$(\boldsymbol{P}-\widetilde{\boldsymbol{P}})\boldsymbol{z} = (\boldsymbol{I}-\widetilde{\boldsymbol{P}})\boldsymbol{Q}\boldsymbol{a} = \widetilde{\boldsymbol{Q}}_\perp\boldsymbol{X}\boldsymbol{a},$$

长度为 $\|\boldsymbol{X}\boldsymbol{a}\|_2 = \sin\theta_{\max}$。两方面合起来即得结论。 ■

谱隙控制的偏转界 现在比较特征子空间。设 $\boldsymbol{S}$、$\widetilde{\boldsymbol{S}} = \boldsymbol{S}+\boldsymbol{E}\in\mathbb{R}^{d\times d}$ 实对称，取 $1\le k<d$，比较两者前 k 个特征值对应的子空间。要使比较有意义，原矩阵的目标特征值组必须与其余特征值分开：设截断处的**谱隙**（spectral gap）

$$\delta = \lambda_k(\boldsymbol{S}) - \lambda_{k+1}(\boldsymbol{S}) > 0,$$

这时 $\boldsymbol{S}$ 前 k 个特征值对应的特征子空间是唯一确定的 k 维子空间。若误差预算满足 $\|\boldsymbol{E}\|_2\le\varepsilon<\delta/2$，由 Weyl 界，

$$\lambda_k(\widetilde{\boldsymbol{S}}) \ge \lambda_k(\boldsymbol{S}) - \varepsilon > \lambda_{k+1}(\boldsymbol{S}) + \varepsilon \ge \lambda_{k+1}(\widetilde{\boldsymbol{S}}),$$

扰动后截断处仍然严格分开，$\widetilde{\boldsymbol{S}}$ 前 k 个特征值的特征子空间也唯一确定，两者都是 k 维，可以用主夹角比较。

下面的论证用到的是交叉谱间隔

$$\gamma = \lambda_k(\boldsymbol{S}) - \lambda_{k+1}(\widetilde{\boldsymbol{S}}),$$

即原目标组的最小特征值与扰动后其余特征值的最大者之差。由 Weyl 界 $\lambda_{k+1}(\widetilde{\boldsymbol{S}}) \le \lambda_{k+1}(\boldsymbol{S}) + \varepsilon$，得 $\gamma \ge \delta - \varepsilon > 0$。

记 $\boldsymbol{Q} \in \mathbb{R}^{d\times k}$ 的列是 $\boldsymbol{S}$ 前 k 个特征值的标准正交特征向量，$\boldsymbol{\Lambda}_1 = \operatorname{diag}(\lambda_1(\boldsymbol{S}),\dots,\lambda_k(\boldsymbol{S}))$；$\widetilde{\boldsymbol{Q}}$ 的列是 $\widetilde{\boldsymbol{S}}$ 前 k 个特征值的标准正交特征向量，$\widetilde{\boldsymbol{Q}}_\perp$ 的列是其余的标准正交特征向量，对应特征值组成对角矩阵 $\widetilde{\boldsymbol{\Lambda}}_2 = \operatorname{diag}(\lambda_{k+1}(\widetilde{\boldsymbol{S}}),\dots,\lambda_d(\widetilde{\boldsymbol{S}}))$。令 $\boldsymbol{X} = \widetilde{\boldsymbol{Q}}_\perp^{\top}\boldsymbol{Q}$，由定理 7.20，它的 Frobenius 范数平方就是两个子空间主夹角正弦的平方和。

定理 7.22　特征子空间偏转的 Frobenius 界　在上述记号下，若 $\gamma = \lambda_k(\boldsymbol{S}) - \lambda_{k+1}(\widetilde{\boldsymbol{S}}) > 0$，则 $\boldsymbol{Q}$ 与 $\widetilde{\boldsymbol{Q}}$ 张成的子空间的主夹角 $\theta_1,\dots,\theta_k$ 满足

$$\Big(\sum_{i=1}^{k}\sin^2\theta_i\Big)^{1/2} = \|\boldsymbol{X}\|_{\mathrm{F}} \le \frac{\|\widetilde{\boldsymbol{Q}}_\perp^{\top}\boldsymbol{E}\boldsymbol{Q}\|_{\mathrm{F}}}{\gamma} \le \frac{\|\boldsymbol{E}\boldsymbol{Q}\|_{\mathrm{F}}}{\gamma}.$$

证明　由特征关系 $\widetilde{\boldsymbol{Q}}_\perp^{\top}\widetilde{\boldsymbol{S}} = \widetilde{\boldsymbol{\Lambda}}_2\widetilde{\boldsymbol{Q}}_\perp^{\top}$（对 $\widetilde{\boldsymbol{S}}\widetilde{\boldsymbol{Q}}_\perp = \widetilde{\boldsymbol{Q}}_\perp\widetilde{\boldsymbol{\Lambda}}_2$ 取转置）右乘 $\boldsymbol{Q}$，又由 $\boldsymbol{S}\boldsymbol{Q} = \boldsymbol{Q}\boldsymbol{\Lambda}_1$ 左乘 $\widetilde{\boldsymbol{Q}}_\perp^{\top}$，两式相减，并用 $\widetilde{\boldsymbol{S}} - \boldsymbol{S} = \boldsymbol{E}$，得

$$\widetilde{\boldsymbol{\Lambda}}_2\boldsymbol{X} - \boldsymbol{X}\boldsymbol{\Lambda}_1 = \widetilde{\boldsymbol{Q}}_\perp^{\top}\boldsymbol{E}\boldsymbol{Q}.$$

这是关于 $\boldsymbol{X}$ 的线性方程，两侧的系数矩阵都是对角的，可以逐元素读出。把 $\boldsymbol{X}$ 的行用 $j = k+1,\dots,d$ 编号、列用 $i = 1,\dots,k$ 编号，第 (j,i) 元满足

$$\big(\lambda_j(\widetilde{\boldsymbol{S}}) - \lambda_i(\boldsymbol{S})\big)X_{j,i} = (\widetilde{\boldsymbol{Q}}_\perp^{\top}\boldsymbol{E}\boldsymbol{Q})_{j,i}.$$

由降序，$i \le k < j$ 时 $\lambda_i(\boldsymbol{S}) - \lambda_j(\widetilde{\boldsymbol{S}}) \ge \lambda_k(\boldsymbol{S}) - \lambda_{k+1}(\widetilde{\boldsymbol{S}}) = \gamma > 0$，所以 $|X_{j,i}| \le |(\widetilde{\boldsymbol{Q}}_\perp^{\top}\boldsymbol{E}\boldsymbol{Q})_{j,i}|/\gamma$。逐元素平方求和，得第一个不等式。$\widetilde{\boldsymbol{Q}}_\perp^{\top}$ 的行标准正交，对任意向量 $\boldsymbol{m}$ 有 $\|\widetilde{\boldsymbol{Q}}_\perp^{\top}\boldsymbol{m}\|_2 \le \|\boldsymbol{m}\|_2$，按列应用于 $\boldsymbol{E}\boldsymbol{Q}$ 即得第二个不等式。等式部分来自定理 7.20。 ∎

证明中出现的方程同时含有左乘和右乘未知矩阵的两项，这类方程称为 Sylvester 方程，第 16.1节专门研究它；这里两侧系数都是对角矩阵，逐元素相除就够了。由 $\|\boldsymbol{E}\boldsymbol{Q}\|_{\mathrm{F}} \le \sqrt{k}\,\|\boldsymbol{E}\|_2$，右端不超过 $\sqrt{k}\,\|\boldsymbol{E}\|_2/\gamma$。

对谱范数，即最大主夹角，也有同型的结论。它不是上面 Frobenius 估计的直接推论：由 Frobenius 界只能得到带因子 $\sqrt{k}$ 的估计。去掉这个因

子要换一种读法：不逐元素相除，而是用 $\boldsymbol{X}$ 的最大奇异方向从两侧检验同一个矩阵方程。

定理 7.23　Davis–Kahan 谱隙界　在定理 7.22的条件下，

$$\|\widetilde{\boldsymbol{P}}-\boldsymbol{P}\|_2=\sin\theta_{\max}\le\frac{\|\boldsymbol{E}\boldsymbol{Q}\|_2}{\gamma}\le\frac{\|\boldsymbol{E}\|_2}{\gamma}. \tag{7.6}$$

证明　由定理 7.21，$\|\widetilde{\boldsymbol{P}}-\boldsymbol{P}\|_2=\sin\theta_{\max}=\|\boldsymbol{X}\|_2$，记 $s=\|\boldsymbol{X}\|_2$。$s=0$ 时结论成立，下设 $s>0$。取 $\boldsymbol{X}$ 的第一右、左奇异向量 $\boldsymbol{a}\in\mathbb{R}^{k}$、$\boldsymbol{b}\in\mathbb{R}^{d-k}$，它们是单位向量，满足 $\boldsymbol{X}\boldsymbol{a}=s\boldsymbol{b}$、$\boldsymbol{X}^{\top}\boldsymbol{b}=s\boldsymbol{a}$。用 $\boldsymbol{b}^{\top}$ 左乘、$\boldsymbol{a}$ 右乘定理 7.22证明中的方程 $\widetilde{\boldsymbol{\Lambda}}_2\boldsymbol{X}-\boldsymbol{X}\boldsymbol{\Lambda}_1=\widetilde{\boldsymbol{Q}}_{\perp}^{\top}\boldsymbol{E}\boldsymbol{Q}$，左端为

$$\begin{aligned}&\boldsymbol{b}^{\top}\widetilde{\boldsymbol{\Lambda}}_2(\boldsymbol{X}\boldsymbol{a})-(\boldsymbol{X}^{\top}\boldsymbol{b})^{\top}\boldsymbol{\Lambda}_1\boldsymbol{a}\\&\quad=s\big(\boldsymbol{b}^{\top}\widetilde{\boldsymbol{\Lambda}}_2\boldsymbol{b}-\boldsymbol{a}^{\top}\boldsymbol{\Lambda}_1\boldsymbol{a}\big).\end{aligned}$$

$\boldsymbol{\Lambda}_1$ 的对角元都不小于 $\lambda_k(\boldsymbol{S})$，$\boldsymbol{a}$ 是单位向量，所以

$$\boldsymbol{a}^{\top}\boldsymbol{\Lambda}_1\boldsymbol{a}=\sum_i\lambda_i(\boldsymbol{S})a_i^2\ge\lambda_k(\boldsymbol{S});$$

同理 $\boldsymbol{b}^{\top}\widetilde{\boldsymbol{\Lambda}}_2\boldsymbol{b}\le\lambda_{k+1}(\widetilde{\boldsymbol{S}})$。于是左端的绝对值至少为 $s\gamma$。右端的绝对值满足

$$|\boldsymbol{b}^{\top}\widetilde{\boldsymbol{Q}}_{\perp}^{\top}\boldsymbol{E}\boldsymbol{Q}\boldsymbol{a}|\le\|\widetilde{\boldsymbol{Q}}_{\perp}\boldsymbol{b}\|_2\,\|\boldsymbol{E}\boldsymbol{Q}\boldsymbol{a}\|_2\le\|\boldsymbol{E}\boldsymbol{Q}\|_2,$$

其中用到 $\|\widetilde{\boldsymbol{Q}}_{\perp}\boldsymbol{b}\|_2=\|\boldsymbol{b}\|_2=1$。所以 $s\gamma\le\|\boldsymbol{E}\boldsymbol{Q}\|_2$，即第一个不等式。最后 $\|\boldsymbol{E}\boldsymbol{Q}\boldsymbol{a}\|_2\le\|\boldsymbol{E}\|_2\|\boldsymbol{Q}\boldsymbol{a}\|_2=\|\boldsymbol{E}\|_2$，得第二个不等式。 ■

这个证明只用到单侧的谱分离：原目标组的特征值都不小于 $\lambda_k(\boldsymbol{S})$，扰动后其余的特征值都不大于 $\lambda_{k+1}(\widetilde{\boldsymbol{S}})$。这正是本节使用的情形；目标组位于谱的中间、两侧都有其余特征值时，需要另作处理，本节不使用。

把交叉间隔换成事先就能检查的量：若已知原谱隙 δ 且 $\|\boldsymbol{E}\|_2\le\varepsilon<\delta/2$，前面已得 $\gamma\ge\delta-\varepsilon$，于是

$$\|\widetilde{\boldsymbol{P}}-\boldsymbol{P}\|_2\le\frac{\varepsilon}{\delta-\varepsilon}\le\frac{2\varepsilon}{\delta},$$

后一个不等号用到 $\delta-\varepsilon>\delta/2$。谱隙在分母上：谱隙越小，同样的扰动能使子空间转过的角度越大。若已经知道交叉间隔 $\gamma>0$，也可以直接使用带 γ 的形式；原谱隙与误差预算只是一组便于事先检查的充分条件。

下面的二维例子可以精确算出转角，并说明子空间的敏感程度不能由矩阵条件数判断。

示例 7.24　谱隙与特征方向的转角　取 $\boldsymbol{S}=\operatorname{diag}(1+\delta,1)$ 与交叉扰动

$$\boldsymbol{E}=t\begin{bmatrix}0&1\\1&0\end{bmatrix},\qquad \delta>0,\ t\ge 0.$$

$\boldsymbol{S}$ 的谱隙为 δ，最大特征方向是 $\boldsymbol{e}_1$，$\|\boldsymbol{E}\|_2=t$。扰动只在非对角位置把两个坐标耦合起来，我们要算出最大特征方向因此转过多大的角度。为了求扰动后的特征向量，先把矩阵写成单位矩阵的倍数加一个迹为零的部分：

$$\boldsymbol{S}+\boldsymbol{E}=\big(1+\tfrac{\delta}{2}\big)\boldsymbol{I}+\boldsymbol{M},\qquad \boldsymbol{M}=\begin{bmatrix}\delta/2&t\\t&-\delta/2\end{bmatrix}.$$

加上单位矩阵的倍数只平移特征值，不改变特征向量，所以只需研究 $\boldsymbol{M}$。记 $r=\sqrt{\delta^2/4+t^2}>0$，取 $\theta\in[0,\pi/4)$ 满足 $\cos 2\theta=\delta/(2r)$、$\sin 2\theta=t/r$，即

$$\tan 2\theta=\frac{2t}{\delta}.$$

于是 $\boldsymbol{M}=r\left[\begin{smallmatrix}\cos 2\theta&\sin 2\theta\\ \sin 2\theta&-\cos 2\theta\end{smallmatrix}\right]$，由两角差公式，

$$\boldsymbol{M}\begin{bmatrix}\cos\theta\\\sin\theta\end{bmatrix}=r\begin{bmatrix}\cos(2\theta-\theta)\\\sin(2\theta-\theta)\end{bmatrix}=r\begin{bmatrix}\cos\theta\\\sin\theta\end{bmatrix}.$$

$\boldsymbol{M}$ 的迹为零，另一个特征值是 $-r$。所以 $\boldsymbol{S}+\boldsymbol{E}$ 的特征值为 $1+\delta/2\pm r$，最大特征方向从 $\boldsymbol{e}_1$ 转到 $(\cos\theta,\sin\theta)^{\top}$，转角 θ 满足 $\tan 2\theta=2t/\delta$。

转角只依赖比值 t/δ，与矩阵的条件数无关。$\boldsymbol{S}$ 的条件数 $\kappa_2(\boldsymbol{S})=1+\delta$，$\delta$ 小时接近 1，按上一节的标准是良态的；但取 $t=\delta/2$ 时，$\tan 2\theta=1$，$\theta=\pi/8=22.5^\circ$：扰动与谱隙相当，方向就明显偏转。同一扰动下，最大特征值只增加 $r-\delta/2\le t$，符合 Weyl 界。所以特征值稳定、条件数小，都不能推出特征方向稳定。

与界 (7.6)比较：交叉间隔 $\gamma=(1+\delta)-(1+\delta/2-r)=\delta/2+r$，界给出 $\sin\theta\le t/(\delta/2+r)$。由 $t^2=r^2-\delta^2/4$ 与 $\cos 2\theta=\delta/(2r)$ 可算出

$$\sin\theta=\sqrt{\frac{r-\delta/2}{2r}}\le\sqrt{\frac{r-\delta/2}{r+\delta/2}}=\frac{t}{\delta/2+r},$$

与界相符；$t\ll\delta$ 时两端都约为 t/δ，界在量级上是准确的。小扰动形式 $2\varepsilon/\delta$ 要求 $t<\delta/2$，例中 $t=\delta/2$ 已在这个条件之外，那里只保留精确算例的结论。图 7.4固定 t，画出最大特征值的增量和转角随谱隙的变化。

重根、奇异子空间与低秩近似　谱隙只需存在于目标特征值组与组外之间，组内的特征值不必彼此分开。取 $\boldsymbol{S}=\operatorname{diag}(2,2,0)$ 与 $k=2$，原谱隙

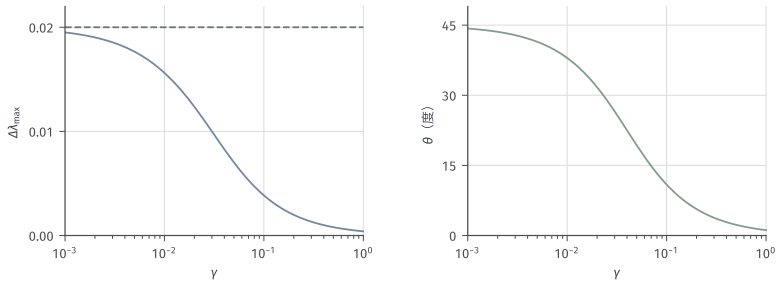


图 7.4 谱隙与特征方向的转角（示例 7.24，$t = 0.02$）。横轴为原谱隙，图中记为 γ，即正文的 δ。左：最大特征值的增量 $r - \delta/2$，始终不超过虚线所示的 t，符合 Weyl 界；右：最大特征方向的转角 $\theta = \frac{1}{2}\arctan(2t/\delta)$。谱隙远大于 t 时转角很小，谱隙小于 t 时转角接近 45°。

$\delta = 2 - 0 = 2$。由上面的推论，$\|\boldsymbol{E}\|_2 \le \varepsilon < 1$ 时，前二维特征子空间的最大主夹角满足 $\sin\theta_{\max} \le \varepsilon/(2-\varepsilon) < \varepsilon$，这个平面是稳定的。

但平面内单个特征向量的选择并不稳定：取 $\eta > 0$，扰动 $\eta\boldsymbol{e}_1\boldsymbol{e}_1^{\top}$ 使最大特征方向成为 $\boldsymbol{e}_1$，扰动 $\eta\boldsymbol{e}_2\boldsymbol{e}_2^{\top}$ 使它成为 $\boldsymbol{e}_2$。无论 η 多小，两个结果都相互正交，而前二维子空间始终是 $\operatorname{span}\{\boldsymbol{e}_1, \boldsymbol{e}_2\}$。所以不能把子空间内部基的变化解释为整个子空间发生了同样大的变化，反过来，子空间稳定也不保证其中每个基向量稳定。

奇异子空间可以通过对称增广矩阵回到特征子空间。设 $\boldsymbol{A}, \boldsymbol{E} \in \mathbb{R}^{m\times n}$，$p = \min(m,n)$，$1 \le k < p$，前 k 个左、右奇异向量排成 $\boldsymbol{U}_k$、$\boldsymbol{V}_k$。要求截断处的奇异值间隙 $\delta_\sigma = \sigma_k(\boldsymbol{A}) - \sigma_{k+1}(\boldsymbol{A}) > 0$，这也保证了所追踪的奇异值 $\sigma_1, \dots, \sigma_k$ 都为正。若 $\sigma_k = 0$，引理 7.14中的 $\boldsymbol{w}_k^{+}$ 与 $\boldsymbol{w}_k^{-}$ 对应同一个特征值 0，就无法从增广矩阵的特征子空间中分出相应的奇异方向。

由该引理，$\boldsymbol{H}(\boldsymbol{A})$ 前 k 个特征值为 $\sigma_1, \dots, \sigma_k$，第 $k+1$ 个为 σ_{k+1}，对应的特征子空间由 $\boldsymbol{w}_i^{+}$（$i \le k$）张成，其正交投影为

$$\boldsymbol{P}_{\boldsymbol{H}} = \frac{1}{2}\begin{bmatrix} \boldsymbol{U}_k\boldsymbol{U}_k^{\top} & \boldsymbol{U}_k\boldsymbol{V}_k^{\top} \\ \boldsymbol{V}_k\boldsymbol{U}_k^{\top} & \boldsymbol{V}_k\boldsymbol{V}_k^{\top} \end{bmatrix}.$$

现在设 $\|\boldsymbol{E}\|_2 \le \varepsilon < \delta_\sigma/2$。由定理 7.15，$\boldsymbol{A} + \boldsymbol{E}$ 在截断处同样分开，对应的投影 $\widetilde{\boldsymbol{P}}_{\boldsymbol{H}}$ 有相同的分块形式。$\boldsymbol{H}(\boldsymbol{E})$ 的谱范数等于 $\|\boldsymbol{E}\|_2$，对增广矩阵使用上面的推论，得 $\|\boldsymbol{P}_{\boldsymbol{H}} - \widetilde{\boldsymbol{P}}_{\boldsymbol{H}}\|_2 \le \varepsilon/(\delta_\sigma - \varepsilon)$。矩阵左上块的谱范数不超过整个矩阵的谱范数（对单位向量 $\boldsymbol{x}$，左上块乘 $\boldsymbol{x}$ 是整个矩阵乘 $(\boldsymbol{x}; \boldsymbol{0})$ 所得向量的上半部分），而 $\boldsymbol{P}_{\boldsymbol{H}} - \widetilde{\boldsymbol{P}}_{\boldsymbol{H}}$ 的左上块是 $\frac{1}{2}(\boldsymbol{U}_k\boldsymbol{U}_k^{\top} - \widetilde{\boldsymbol{U}}_k\widetilde{\boldsymbol{U}}_k^{\top})$，所以

$$\|\boldsymbol{U}_k\boldsymbol{U}_k^{\top} - \widetilde{\boldsymbol{U}}_k\widetilde{\boldsymbol{U}}_k^{\top}\|_2 \le \frac{2\varepsilon}{\delta_\sigma - \varepsilon} \le \frac{4\varepsilon}{\delta_\sigma},$$

右下块给出右奇异子空间的同样结论。可见左、右奇异子空间的稳定性由截断处的间隙 δ_σ 控制。

与上一小节对照：最佳秩 k 逼近的误差 σ_{k+1} 在任何情况下都只移动不超过 ε，而取得这个误差所用的主方向只在截断处有足够间隙时才稳定。$\sigma_k = \sigma_{k+1}$ 时，最优误差仍然稳定，最优的秩 k 矩阵却可能在不同的子空间之间跳变。第 14.2节的截断求解直接用到这个区别：选取截断位置时，既要看被舍弃的奇异值是否可以忽略，也要看保留的方向是否与舍弃的方向分得开。

7.2.4　一般方阵的谱敏感性

前面按序比较特征值的界依靠对称结构：特征值是实数，可以排序，并能由二次型在特征子空间上的取值刻画。一般方阵的特征值可能是复数，没有自然的次序，二次型也不再与特征值对应。下面对可对角化的方阵研究另一个问题：$\boldsymbol{A}+\boldsymbol{E}$ 的某个特征值离 $\boldsymbol{A}$ 的谱有多远。这里允许在复数域中选取特征基，向量使用复欧氏范数 $\|\boldsymbol{z}\|_2 = (\sum_i |z_i|^2)^{1/2}$，矩阵使用相应的诱导范数。

定理 7.25　Bauer–Fike　设 $\boldsymbol{A} \in \mathbb{C}^{n\times n}$ 可对角化，$\boldsymbol{A} = \boldsymbol{V}\boldsymbol{\Lambda}\boldsymbol{V}^{-1}$，其中 $\boldsymbol{\Lambda} = \operatorname{diag}(\lambda_1, \dots, \lambda_n)$，$\boldsymbol{V}$ 可逆；记 $\kappa_2(\boldsymbol{V}) = \|\boldsymbol{V}\|_2\|\boldsymbol{V}^{-1}\|_2$。则对任意 $\boldsymbol{E} \in \mathbb{C}^{n\times n}$ 与 $\boldsymbol{A}+\boldsymbol{E}$ 的任一特征值 μ，

$$\min_{1\le i\le n} |\mu - \lambda_i| \le \kappa_2(\boldsymbol{V})\|\boldsymbol{E}\|_2.$$

证明　若 μ 是 $\boldsymbol{A}$ 的特征值，左端为零，结论成立。下设 μ 不是 $\boldsymbol{A}$ 的特征值，于是对角矩阵 $\boldsymbol{\Lambda}-\mu\boldsymbol{I}$ 可逆。取 $\boldsymbol{A}+\boldsymbol{E}$ 对应于 μ 的特征向量 $\boldsymbol{w} \neq \boldsymbol{0}$，由 $(\boldsymbol{A}+\boldsymbol{E})\boldsymbol{w} = \mu\boldsymbol{w}$ 得 $(\boldsymbol{A}-\mu\boldsymbol{I})\boldsymbol{w} = -\boldsymbol{E}\boldsymbol{w}$。代入 $\boldsymbol{A}-\mu\boldsymbol{I} = \boldsymbol{V}(\boldsymbol{\Lambda}-\mu\boldsymbol{I})\boldsymbol{V}^{-1}$，令 $\boldsymbol{y} = \boldsymbol{V}^{-1}\boldsymbol{w} \neq \boldsymbol{0}$，得

$$\boldsymbol{y} = -(\boldsymbol{\Lambda} - \mu\boldsymbol{I})^{-1}\boldsymbol{V}^{-1}\boldsymbol{E}\boldsymbol{V}\boldsymbol{y}.$$

两边取范数，

$$\begin{aligned}\|\boldsymbol{y}\|_2 &\le \|(\boldsymbol{\Lambda} - \mu\boldsymbol{I})^{-1}\|_2\,\|\boldsymbol{V}^{-1}\boldsymbol{E}\boldsymbol{V}\|_2\,\|\boldsymbol{y}\|_2 \\ &\le \|(\boldsymbol{\Lambda} - \mu\boldsymbol{I})^{-1}\|_2\,\kappa_2(\boldsymbol{V})\|\boldsymbol{E}\|_2\,\|\boldsymbol{y}\|_2.\end{aligned}$$

对角矩阵 $\boldsymbol{D} = \operatorname{diag}(d_i)$ 满足 $\|\boldsymbol{D}\boldsymbol{z}\|_2^2 = \sum_i |d_i|^2|z_i|^2 \le \max_i |d_i|^2\|\boldsymbol{z}\|_2^2$，且在相应的坐标向量处取等号，所以 $\|(\boldsymbol{\Lambda}-\mu\boldsymbol{I})^{-1}\|_2 = 1/\min_i|\lambda_i-\mu|$。代入并除以 $\|\boldsymbol{y}\|_2 > 0$，得 $1 \le \kappa_2(\boldsymbol{V})\|\boldsymbol{E}\|_2/\min_i|\lambda_i-\mu|$，整理即得结论。 ∎

界中出现的是所选特征基的条件数 $\kappa_2(\boldsymbol{V})$，而不是上一节的 $\kappa_2(\boldsymbol{A})$，二者衡量不同的东西。$\boldsymbol{A}=\operatorname{diag}(1,s)$（$0<s<1$）可取 $\boldsymbol{V}=\boldsymbol{I}$，$\kappa_2(\boldsymbol{V})=1$，任何扰动都只能使特征值移动不超过 $\|\boldsymbol{E}\|_2$，而 $\kappa_2(\boldsymbol{A})=1/s$ 可以很大。

反过来，求逆不敏感的矩阵也可能有敏感的特征值。取 $\eta>0$ 与

$$\boldsymbol{A}=\begin{bmatrix}1 & 1\\ 0 & 1+\eta\end{bmatrix},\qquad \boldsymbol{V}=\begin{bmatrix}1 & 1\\ 0 & \eta\end{bmatrix},$$

由 $\boldsymbol{A}(1,0)^{\mathsf{T}}=(1,0)^{\mathsf{T}}$ 与 $\boldsymbol{A}(1,\eta)^{\mathsf{T}}=(1+\eta)(1,\eta)^{\mathsf{T}}$，$\boldsymbol{V}$ 的两列是特征值 1 与 $1+\eta$ 的特征向量。$\eta\to 0$ 时，$\boldsymbol{A}$ 趋于 $\boldsymbol{A}_0=\left[\begin{smallmatrix}1&1\\0&1\end{smallmatrix}\right]$：$\boldsymbol{A}_0^{\mathsf{T}}\boldsymbol{A}_0=\left[\begin{smallmatrix}1&1\\1&2\end{smallmatrix}\right]$ 的特征值为 $(3\pm\sqrt{5})/2$，乘积为 1，所以 $\kappa_2(\boldsymbol{A}_0)=\sqrt{(3+\sqrt{5})/(3-\sqrt{5})}=(3+\sqrt{5})/2\approx 2.62$；又 $\|\boldsymbol{A}-\boldsymbol{A}_0\|_2=\eta$，由定理 7.15，$\boldsymbol{A}$ 的两个奇异值与 $\boldsymbol{A}_0$ 的相差不超过 η，$\kappa_2(\boldsymbol{A})$ 随之趋于 $\kappa_2(\boldsymbol{A}_0)$，求逆并不敏感。

但两个特征向量越来越接近平行：$\det(\boldsymbol{V}^{\mathsf{T}}\boldsymbol{V})=(\det\boldsymbol{V})^2$，所以 $\boldsymbol{V}$ 的两个奇异值之积为 $|\det\boldsymbol{V}|=\eta$，而最大奇异值不小于 $\|\boldsymbol{V}\boldsymbol{e}_1\|_2=1$，故 $\kappa_2(\boldsymbol{V})\ge 1/\eta$，Bauer–Fike 界变得很宽。非正交的特征基会放大扰动在特征坐标中的表示，这是一般方阵特征值敏感的来源；对称矩阵可取正交的 $\boldsymbol{V}$，$\kappa_2(\boldsymbol{V})=1$，界与 Weyl 界同量级。

使用这个界时还要注意三点。第一，特征向量的缩放会改变 $\boldsymbol{V}$ 的条件数，界对任意一组特征基成立，引用时须说明所用的基，通常取使 $\kappa_2(\boldsymbol{V})$ 较小的一组。第二，它只保证每个扰动后的特征值接近某个原特征值，不建立逐个特征值的固定配对，也不恢复对称情形的有序比较。第三，它要求 $\boldsymbol{A}$ 可对角化；特征向量不足时，特征值的变化可以与扰动不成比例。

示例 7.26　特征值的移动远大于扰动　取不可对角化的

$$\boldsymbol{A}=\begin{bmatrix}0 & 1\\ 0 & 0\end{bmatrix},$$

它的特征值全为 0，特征空间只有一维。在左下角放一个大小为 t 的扰动 $\boldsymbol{E}=\left[\begin{smallmatrix}0&0\\t&0\end{smallmatrix}\right]$，$t>0$，则 $\|\boldsymbol{E}\|_2=t$，而

$$\boldsymbol{A}+\boldsymbol{E}=\begin{bmatrix}0 & 1\\ t & 0\end{bmatrix},\qquad \det\bigl(z\boldsymbol{I}-(\boldsymbol{A}+\boldsymbol{E})\bigr)=z^2-t,$$

特征值为 $\pm\sqrt{t}$，移动量为 $\sqrt{t}$。扰动越小，这个比例反而越悬殊：$t=10^{-10}$ 时特征值移动 10^{-5}，是扰动大小的 10^5 倍。由于 $\sqrt{t}/t\to\infty$（$t\to 0^+$），不存在常数 c 使移动量对所有小扰动都不超过 $c\|\boldsymbol{E}\|_2$，Bauer–Fike 那样与扰动成比例的界在这里不可能成立。若改取 $t<0$，特征值为 $\pm\mathrm{i}\sqrt{|t|}$，实特征值随之消失。

这个例子说明，缺少可对角化条件时，特征值的变化可以出现与扰动不同的量级；本节不为此引入新的标准形体系。第 20.3.2节在相应光滑分支存在时研究一阶响应；本节的有限变化界则始终要连同对象的结构（对称、可对角化）和谱的分离条件一起使用。

综合起来，把矩阵本身当作输入时：对称矩阵的特征值与任意矩阵的奇异值都随扰动有界地移动，移动量不超过 $\|\boldsymbol{E}\|_2$，并且不要求谱值分开，由此可以可靠地判断符号、正定性和秩的下界；所选子空间的方向要用主夹角比较，偏转由扰动与谱隙之比控制；一般方阵的特征值还取决于特征基的条件，甚至不与扰动成比例。条件数与谱的扰动讨论的都是一次作用或一次分解；同一个矩阵的反复作用留给第 8章。

7.3 本章小结

本章开头问：只知道误差大小的上限时，由手中的数据算出的结论还有多可靠？答案要先分清误差在哪里，再分清关心的是哪一种输出。

误差在输入向量上、矩阵固定时，线性性给出对任意大小扰动都成立的精确增量 $\boldsymbol{A}\boldsymbol{h}$。绝对误差最多放大 $\sigma_{\max}(\boldsymbol{A})$ 倍，沿最大右奇异方向达到。相对误差的放大还取决于基点：固定输入处的相对条件数是 $\|\boldsymbol{A}\|_2\|\boldsymbol{x}\|_2/\|\boldsymbol{A}\boldsymbol{x}\|_2$，输入落在被压缩的方向上时它大；对输入也取最坏值，得到矩阵条件数 $\kappa_2(\boldsymbol{A}) = \sigma_{\max}/\sigma_{\min}$，它衡量最强与最弱作用之差，不衡量矩阵元素的大小，也不描述反复作用的长期趋势。

误差在矩阵本身上时，不同输出有不同的稳定性条件。对称矩阵按序配对的特征值与任意矩阵的奇异值都移动不超过 $\|\boldsymbol{E}\|_2$，不要求谱值彼此分开；据此，区间不含零的特征值保持符号，$\lambda_{\min}(\boldsymbol{S}) > \varepsilon$ 保证正定，$\sigma_k(\boldsymbol{A}) > \varepsilon$ 保证秩至少为 k。可逆矩阵到奇异矩阵的谱范数距离恰为 $\sigma_{\min}$，相对距离为 $1/\kappa_2(\boldsymbol{A})$。精确秩会在任意小的扰动下跳变，可靠的只是给定误差预算下的有效秩。

所选的特征子空间要用主夹角或投影之差比较，单个特征向量的变化不能代表子空间的变化。偏转由扰动与谱隙之比控制：交叉间隔 $\gamma > 0$ 时 $\sin\theta_{\max} \le \|\boldsymbol{E}\|_2/\gamma$，已知原谱隙 δ 且 $\varepsilon < \delta/2$ 时不超过 $2\varepsilon/\delta$。重特征值内部的基不稳定，但只要目标组与其余谱分开，整个子空间稳定；奇异子空间由截断处的奇异值间隙控制。

一般方阵没有对称结构。可对角化时，Bauer–Fike 界使扰动后的特征值离原谱不超过 $\kappa_2(\boldsymbol{V})\|\boldsymbol{E}\|_2$，敏感性由特征基的条件数而不是 $\kappa_2(\boldsymbol{A})$ 决定；不可对角化时，特征值的移动可以与扰动不成比例，例如 $\sqrt{t}$ 对 t。

所以判断一个谱或分解的结果是否可靠，要同时说明对象的结构（对称、可对角化）、所用的分离条件（谱隙、奇异值间隙）和误差预算；仅凭 $\kappa_2(\boldsymbol{A})$ 不能判断特征值或子空间是否敏感。这些界都是有限变化界，沿指

定方向的一阶响应与带余项的近似误差在第 20章讨论。下一章转向同一个矩阵的反复作用：误差每一步都要再经过一次作用，长期结果由谱半径决定。

第 8 章

线性递推的收敛与稳定性

第 7章研究的是一次作用：输入或矩阵有误差时，结果能变化多少。许多计算却反复执行同一个更新：给定实方阵 $\boldsymbol{T} \in \mathbb{R}^{d\times d}$ 与向量 $\boldsymbol{c} \in \mathbb{R}^{d}$，从初值 $\boldsymbol{x}_0$ 出发，令

$$\boldsymbol{x}_{k+1} = \boldsymbol{T}\boldsymbol{x}_k + \boldsymbol{c}, \qquad k = 0, 1, 2, \ldots$$

每一轮先对当前状态作同一个线性变换，再加入同一个输入。本章要回答的问题是：无论从哪里出发，这些状态能否趋于同一个平衡？如果能，平衡在哪里，接近得多快？每一轮计算若带有小误差，误差会累积到多大？

第 8.1节展开递推，把状态拆成“初值经过 k 次作用后的剩余影响”与“历次输入的累积”两部分：前者由矩阵幂 $\boldsymbol{T}^k$ 描述，后者由矩阵级数 $\sum_j \boldsymbol{T}^j$ 描述。第 8.2节证明初值影响全部消失当且仅当谱半径 $\rho(\boldsymbol{T}) < 1$，这比每一步都收缩的范数条件更一般。第 8.3节在同一条件下用 Neumann 级数求出输入的累积与共同的极限。第 8.4节估计接近平衡的速度，并说明非正规矩阵可能先放大、再衰减。第 8.5节把每一步的附加误差当作新的输入，比较有界、趋零和可求和的误差对最终精度的影响。

本章用到第 4章的特征值、实 Schur 形、谱半径与正规矩阵，以及第 5章的谱范数。本章只分析给定的 $\boldsymbol{T}$ 与 $\boldsymbol{c}$；如何从线性方程出发构造计算便宜且能收敛的更新规则，留给第 11章。

本章的收敛按第 3.2.1节理解：向量列或矩阵列收敛，等价于每个坐标或每个元素组成的实数列收敛（定理 3.10）；由有限维范数等价（定理 3.27），收敛与否不随所选范数改变。所以下面主要在二范数下估计，$\|\boldsymbol{T}^k\|_2 \to 0$ 就是 $\boldsymbol{T}^k \to \boldsymbol{0}$。矩阵级数按第 3.3.3节的部分和定义收敛，并使用那里的绝对收敛判据。

8.1 递推解的表示

先用一个二维例子看更新规则怎样逐步推进。本章始终用它说明各个结论。

示例 8.1　贯穿本章的更新　取

$$\boldsymbol{T}=\begin{bmatrix}1/2 & 1\\ 0 & 1/2\end{bmatrix},\qquad \boldsymbol{c}=\begin{bmatrix}0\\ 1\end{bmatrix}.$$

写成分量，更新是 $x_{k+1,1}=\frac{1}{2}x_{k,1}+x_{k,2}$ 与 $x_{k+1,2}=\frac{1}{2}x_{k,2}+1$：两个分量每轮各保留一半，第二个分量还把当前值传给第一个分量，随后第二个分量补入 1。从 $\boldsymbol{x}_0=\boldsymbol{0}$ 出发逐步计算，前三步是

$$\boldsymbol{x}_1=\begin{bmatrix}0\\ 1\end{bmatrix},\quad \boldsymbol{x}_2=\begin{bmatrix}1\\ 3/2\end{bmatrix},\quad \boldsymbol{x}_3=\begin{bmatrix}2\\ 7/4\end{bmatrix}.$$

每一步都只是把上一步代入更新规则，例如 $\boldsymbol{x}_3=\boldsymbol{T}\boldsymbol{x}_2+\boldsymbol{c}=(\frac{1}{2}+\frac{3}{2},\frac{3}{4})^{\mathsf{T}}+(0,1)^{\mathsf{T}}$。

三步之后，第二个分量的增量依次为 $1/2$、$1/4$，似乎在接近 2；第一个分量每步增加 1，看不出是否有界。换一个初值，结果是否相同，也不能由这几步判断。要回答这些问题，先把 $\boldsymbol{x}_k$ 直接写成初值与输入的表达式。

引理 8.2　递推的有限展开　对任意初值 $\boldsymbol{x}_0$ 与 $k\ge 0$，

$$\boldsymbol{x}_k=\boldsymbol{T}^k\boldsymbol{x}_0+\sum_{j=0}^{k-1}\boldsymbol{T}^j\boldsymbol{c},$$

其中 $k=0$ 时和式为空，取为 $\boldsymbol{0}$。

证明　对 k 归纳。$k=0$ 时两边都是 $\boldsymbol{x}_0$。设结论对 k 成立，代入更新规则，

$$\begin{aligned}\boldsymbol{x}_{k+1}&=\boldsymbol{T}\Big(\boldsymbol{T}^k\boldsymbol{x}_0+\sum_{j=0}^{k-1}\boldsymbol{T}^j\boldsymbol{c}\Big)+\boldsymbol{c}\\ &=\boldsymbol{T}^{k+1}\boldsymbol{x}_0+\sum_{j=1}^{k}\boldsymbol{T}^j\boldsymbol{c}+\boldsymbol{T}^0\boldsymbol{c},\end{aligned}$$

这里用了矩阵乘法对加法的分配律，并把和式的指标平移一位。末两项合起来是 $\sum_{j=0}^{k}\boldsymbol{T}^j\boldsymbol{c}$，结论对 $k+1$ 成立。 ∎

展开式的第一项 $\boldsymbol{T}^k\boldsymbol{x}_0$ 记录最初状态经过 k 轮作用后的剩余影响。和式中的 $\boldsymbol{T}^j\boldsymbol{c}$ 是 j 轮之前加入的输入再经过 j 次作用的结果，和式把各轮输入的贡献加在一起。$\boldsymbol{c}=\boldsymbol{0}$ 时，只剩下反复施加同一矩阵的轨迹 $\boldsymbol{T}^k\boldsymbol{x}_0$。这里只作了有限展开，还没有假定极限或平衡存在。

比较相同 $\boldsymbol{T},\boldsymbol{c}$ 而初值不同的两条轨迹 $\boldsymbol{x}_k$ 与 $\widetilde{\boldsymbol{x}}_k$。两者的展开式中输入部分相同，相减后只剩

$$\boldsymbol{x}_k-\widetilde{\boldsymbol{x}}_k=\boldsymbol{T}^k(\boldsymbol{x}_0-\widetilde{\boldsymbol{x}}_0).$$

所以“初值是否影响最终结果”只取决于矩阵幂对初始差的作用。只看某一个初始差并不够，下面把“所有初始差都消失”写成关于 $\boldsymbol{T}^k$ 本身的条件。

引理 8.3　初值差异消失的条件　对固定的 $\boldsymbol{T}$ 与 $\boldsymbol{c}$，以下两条等价：

1. 对任意两个初值 $\boldsymbol{x}_0,\widetilde{\boldsymbol{x}}_0$，相应轨迹满足 $\boldsymbol{x}_k-\widetilde{\boldsymbol{x}}_k\to\boldsymbol{0}$；
2. $\boldsymbol{T}^k\to\boldsymbol{0}$。

证明　由上式，第一条等价于：对任意 $\boldsymbol{v}\in\mathbb{R}^d$ 都有 $\boldsymbol{T}^k\boldsymbol{v}\to\boldsymbol{0}$。

设 $\boldsymbol{T}^k\to\boldsymbol{0}$。按定义 $\|\boldsymbol{T}^k\|_{\mathrm{F}}\to 0$，而二范数不超过 Frobenius 范数，故对任意 $\boldsymbol{v}$，

$$\begin{aligned}\|\boldsymbol{T}^k\boldsymbol{v}\|_2&\le\|\boldsymbol{T}^k\|_2\|\boldsymbol{v}\|_2\\&\le\|\boldsymbol{T}^k\|_{\mathrm{F}}\|\boldsymbol{v}\|_2\to 0.\end{aligned}$$

反过来，设对任意 $\boldsymbol{v}$ 都有 $\boldsymbol{T}^k\boldsymbol{v}\to\boldsymbol{0}$。依次取 $\boldsymbol{v}=\boldsymbol{e}_1,\dots,\boldsymbol{e}_d$，$\boldsymbol{T}^k\boldsymbol{e}_j$ 是 $\boldsymbol{T}^k$ 的第 j 列，所以每一列都趋于零。由定理 3.10，每列的各个元素趋于零，于是 $\boldsymbol{T}^k$ 的每个元素趋于零，再由同一定理得 $\boldsymbol{T}^k\to\boldsymbol{0}$。 ■

因此，要判断初值的影响能否全部消失，先研究矩阵幂 $\boldsymbol{T}^k$ 何时趋于零；之后再回到展开式中的输入累积，寻找共同的极限。

8.2　初值影响的衰减

一个便于检验的充分条件来自范数。若某个次乘性矩阵范数满足 $\|\boldsymbol{T}\|<1$，则 $\|\boldsymbol{T}^k\|\le\|\boldsymbol{T}\|^k\to 0$，由范数等价即 $\boldsymbol{T}^k\to\boldsymbol{0}$。在诱导范数下，这表示每一轮作用都把任何差异缩短到原来的 $\|\boldsymbol{T}\|$ 倍以内。

贯穿例说明这个条件不必要。$\boldsymbol{T}(0,1)^{\top}=(1,1/2)^{\top}$，长度为 $\sqrt{5}/2>1$，所以 $\|\boldsymbol{T}\|_2>1$；由第 3.3.4节的列和与行和公式，$\|\boldsymbol{T}\|_1=\|\boldsymbol{T}\|_\infty=3/2$，也都大于 1。可是示例 3.31已经由归纳算出

$$\boldsymbol{T}^k=2^{-k}\begin{bmatrix}1&2k\\0&1\end{bmatrix},$$

由 $k2^{-k}\to 0$，各元素都趋于零，$\boldsymbol{T}^k\to\boldsymbol{0}$。$\boldsymbol{T}$ 是上三角矩阵，特征值为对角元 $1/2$，谱半径 $\rho(\boldsymbol{T})=1/2$。

这个 $\boldsymbol{T}$ 不正规：$\boldsymbol{T}^{\top}\boldsymbol{T}$ 的 $(1,1)$ 元为 $1/4$，$\boldsymbol{T}\boldsymbol{T}^{\top}$ 的 $(1,1)$ 元为 $1/4+1=5/4$。对角线上方的耦合使单步放大倍数超过 1；第 4.4节已经指出，非正规矩阵的范数可以远大于谱半径。所以需要一个能覆盖非正规矩阵、只依赖谱半径的判据。

下面的引理是这个判据的核心。它先用相似变换把实 Schur 形的每个对角块化为模长乘旋转，再用逐块的坐标缩放把对角线上方的块压小，构造一个使 $\boldsymbol{T}$ 的诱导范数不超过 r 的坐标范数，从而得到以略大于谱半径的 r 为底的几何上界。为了不与更新矩阵混淆，下面把 $\boldsymbol{T}$ 的实 Schur 形（定理 4.26）记为 $\boldsymbol{U}$。

引理 8.4　矩阵幂的几何上界　对任意 $r>\rho(\boldsymbol{T})$，存在可逆矩阵 $\boldsymbol{M}$，使 $\boldsymbol{T}$ 在坐标范数 $\|\boldsymbol{x}\|_{*}=\|\boldsymbol{M}^{-1}\boldsymbol{x}\|_{2}$ 诱导的矩阵范数下满足 $\|\boldsymbol{T}\|_{*}\le r$；从而存在常数 C_r，使 $\|\boldsymbol{T}^{k}\|_{2}\le C_r r^{k}$ 对所有 $k\ge 0$ 成立。

证明　取实 Schur 形 $\boldsymbol{T}=\boldsymbol{Q}\boldsymbol{U}\boldsymbol{Q}^{\top}$，其中 $\boldsymbol{Q}$ 正交，$\boldsymbol{U}$ 分块上三角。设 $\boldsymbol{U}$ 有 s 个对角块，第 i 块的特征值模长为 $|\lambda_i|$。

先处理对角块。每个 2×2 对角块 $\boldsymbol{U}_{i,i}$ 有一对共轭特征值，按第 4.4节的论证，在复特征向量的实部、虚部组成的基下，它化为模长乘旋转：$\boldsymbol{U}_{i,i}=\boldsymbol{P}_i(|\lambda_i|\boldsymbol{R}_i)\boldsymbol{P}_i^{-1}$，$\boldsymbol{R}_i$ 为旋转矩阵；1×1 块取 $\boldsymbol{P}_i=1$、$\boldsymbol{R}_i=\pm 1$。

再压小非对角块。对 $0<\varepsilon\le 1$，令分块对角矩阵

$$\boldsymbol{D}_{\varepsilon}=\operatorname{diag}(\varepsilon^{0}\boldsymbol{P}_1,\varepsilon^{1}\boldsymbol{P}_2,\dots,\varepsilon^{s-1}\boldsymbol{P}_s).$$

直接相乘，$\boldsymbol{D}_{\varepsilon}^{-1}\boldsymbol{U}\boldsymbol{D}_{\varepsilon}$ 的第 (i,j) 块为 $\varepsilon^{j-i}\boldsymbol{P}_i^{-1}\boldsymbol{U}_{i,j}\boldsymbol{P}_j$：对角块是 $|\lambda_i|\boldsymbol{R}_i$；$j>i$ 的块带有因子 $\varepsilon^{j-i}\le\varepsilon$，所以全部非对角块组成的矩阵，其 Frobenius 范数不超过 εc，其中 c 是由各块 $\boldsymbol{P}_i^{-1}\boldsymbol{U}_{i,j}\boldsymbol{P}_j$（$j>i$）组成的矩阵的 Frobenius 范数，与 ε 无关。把矩阵拆成分块对角部分与非对角部分，得

$$\|\boldsymbol{D}_{\varepsilon}^{-1}\boldsymbol{U}\boldsymbol{D}_{\varepsilon}\|_{2}\le\rho(\boldsymbol{T})+\varepsilon c.$$

这里分块对角部分的二范数不超过 $\rho(\boldsymbol{T})$，是因为把输入按块写成 $\boldsymbol{x}=(\boldsymbol{x}_1,\dots,\boldsymbol{x}_s)$ 后，输出的平方长度是 $\sum_i|\lambda_i|^2\|\boldsymbol{R}_i\boldsymbol{x}_i\|_2^2\le\rho(\boldsymbol{T})^2\|\boldsymbol{x}\|_2^2$；非对角部分则用二范数不超过 Frobenius 范数估计。取 ε 足够小，使右端不超过 r。

最后构造坐标范数并换回原坐标。令 $\boldsymbol{M}=\boldsymbol{Q}\boldsymbol{D}_{\varepsilon}$，则 $\boldsymbol{M}^{-1}\boldsymbol{T}\boldsymbol{M}=\boldsymbol{D}_{\varepsilon}^{-1}\boldsymbol{U}\boldsymbol{D}_{\varepsilon}$。$\boldsymbol{M}$ 可逆，$\|\boldsymbol{x}\|_{*}=\|\boldsymbol{M}^{-1}\boldsymbol{x}\|_{2}$ 是一个向量范数：齐次性与三角不等式由 $\boldsymbol{x}\mapsto\boldsymbol{M}^{-1}\boldsymbol{x}$ 的线性和欧氏范数的相应性质得到，而

$\|\boldsymbol{x}\|_* = 0$ 意味着 $\boldsymbol{M}^{-1}\boldsymbol{x} = \boldsymbol{0}$，由 $\boldsymbol{M}^{-1}$ 可逆得 $\boldsymbol{x} = \boldsymbol{0}$。它就是在新坐标 $\boldsymbol{M}^{-1}\boldsymbol{x}$ 下量取的欧氏长度。令 $\boldsymbol{x} = \boldsymbol{M}\boldsymbol{y}$，它诱导的矩阵范数为

$$\begin{aligned}\|\boldsymbol{B}\|_* &= \sup_{\boldsymbol{x}\neq\boldsymbol{0}} \frac{\|\boldsymbol{M}^{-1}\boldsymbol{B}\boldsymbol{x}\|_2}{\|\boldsymbol{M}^{-1}\boldsymbol{x}\|_2} \\ &= \sup_{\boldsymbol{y}\neq\boldsymbol{0}} \frac{\|\boldsymbol{M}^{-1}\boldsymbol{B}\boldsymbol{M}\boldsymbol{y}\|_2}{\|\boldsymbol{y}\|_2} = \|\boldsymbol{M}^{-1}\boldsymbol{B}\boldsymbol{M}\|_2 .\end{aligned}$$

取 $\boldsymbol{B} = \boldsymbol{T}$，得 $\|\boldsymbol{T}\|_* = \|\boldsymbol{D}_\varepsilon^{-1}\boldsymbol{U}\boldsymbol{D}_\varepsilon\|_2 \le r$。诱导范数满足次乘性，故 $\|\boldsymbol{T}^k\|_* \le r^k$。再由 $\boldsymbol{T}^k = \boldsymbol{M}(\boldsymbol{M}^{-1}\boldsymbol{T}^k\boldsymbol{M})\boldsymbol{M}^{-1}$ 及二范数的次乘性，

$$\begin{aligned}\|\boldsymbol{T}^k\|_2 &\le \|\boldsymbol{M}\|_2\|\boldsymbol{M}^{-1}\boldsymbol{T}^k\boldsymbol{M}\|_2\|\boldsymbol{M}^{-1}\|_2 \\ &= \|\boldsymbol{M}\|_2\|\boldsymbol{M}^{-1}\|_2\|\boldsymbol{T}^k\|_* \\ &\le \|\boldsymbol{M}\|_2\|\boldsymbol{M}^{-1}\|_2\, r^k ,\end{aligned}$$

取 $C_r = \|\boldsymbol{M}\|_2\|\boldsymbol{M}^{-1}\|_2$ 即可。 ■

常数 C_r 只依赖固定的换基矩阵 $\boldsymbol{M}$，与 k 无关；但 $\boldsymbol{M}$ 随 r 选取，常数也随 r 改变。几何上界也不表示原范数下每一步都收缩：只有在坐标范数 $\|\cdot\|_*$ 中，$\boldsymbol{T}$ 的每次作用才不超过 r 倍；换回二范数，单步放大倍数 $\|\boldsymbol{T}\|_2$ 仍可能大于 1。下面在贯穿例中具体走一遍这个构造。

示例 8.5　贯穿例的坐标范数　贯穿例的 $\boldsymbol{T}$ 已经是上三角矩阵，构造中的前两步都不必做：可取 $\boldsymbol{Q} = \boldsymbol{I}$，两个 1×1 对角块的 $\boldsymbol{P}_i = 1$，于是 $\boldsymbol{M} = \boldsymbol{D}_\varepsilon = \mathrm{diag}(1, \varepsilon)$，且

$$\boldsymbol{M}^{-1}\boldsymbol{T}\boldsymbol{M} = \begin{bmatrix} 1/2 & \varepsilon \\ 0 & 1/2 \end{bmatrix}.$$

缩放把右上角的耦合从 1 压到 ε，对角元不变。取 $\varepsilon = 1/4$，剩下的任务是算出这个矩阵的二范数。为此对 $a, b > 0$ 考虑一般的 $\boldsymbol{G} = \left[\begin{smallmatrix} a & b \\ 0 & a \end{smallmatrix}\right]$。由式 (5.5)，$\|\boldsymbol{G}\|_2$ 是最大奇异值，其平方是 $\boldsymbol{G}^{\top}\boldsymbol{G} = \left[\begin{smallmatrix} a^2 & ab \\ ab & a^2+b^2 \end{smallmatrix}\right]$ 的最大特征值（第 5章）。这个矩阵的迹为 $2a^2 + b^2$、行列式为 a^4，最大特征值为

$$\mu = \frac{2a^2 + b^2 + b\sqrt{b^2 + 4a^2}}{2} = \left(\frac{b + \sqrt{b^2 + 4a^2}}{2}\right)^2 ,$$

第二个等号展开右端平方即可验证。所以 $\|\boldsymbol{G}\|_2 = (b+\sqrt{b^2+4a^2})/2$。代入 $a=1/2$、$b=1/4$ 得

$$\|\boldsymbol{T}\|_* = \frac{1+\sqrt{17}}{8} \approx 0.640,$$

其中 $\|\boldsymbol{x}\|_* = \|\boldsymbol{M}^{-1}\boldsymbol{x}\|_2 = \sqrt{x_1^2+16x_2^2}$。这个值小于 1，但比 $\rho(\boldsymbol{T})=1/2$ 大一些，对应引理中的 r。

换回欧氏范数还需要常数 $\|\boldsymbol{M}\|_2\|\boldsymbol{M}^{-1}\|_2$。对角矩阵 $\operatorname{diag}(d_1,d_2)$ 满足 $\|\operatorname{diag}(d_1,d_2)\boldsymbol{x}\|_2^2 = d_1^2x_1^2+d_2^2x_2^2 \le \max_i d_i^2\|\boldsymbol{x}\|_2^2$，且在相应的标准基向量处取等号，故其二范数为 $\max_i|d_i|$。于是 $\|\boldsymbol{M}\|_2=1$、$\|\boldsymbol{M}^{-1}\|_2 = \|\operatorname{diag}(1,4)\|_2 = 4$，所以 $\|\boldsymbol{T}^k\|_2 \le 4\times 0.641^k$。在加大了第二坐标权重的范数中，$\boldsymbol{T}$ 每一步都收缩；换回欧氏长度，代价是常数 4。

能否把 ε 取得更小，直接让 $r=\rho(\boldsymbol{T})=1/2$？不能。由 $\boldsymbol{T}^k$ 的显式式，$\|\boldsymbol{T}^k\|_2 \ge \|\boldsymbol{T}^k\boldsymbol{e}_2\|_2 \ge k2^{1-k}$，即 $\|\boldsymbol{T}^k\|_2/2^{-k} \ge 2k$，没有与 k 无关的常数能控制它；所以引理中的 r 必须严格大于谱半径。

有了几何上界，就能给出矩阵幂衰减的充要条件。

定理 8.6　矩阵幂的衰减判据　对实方阵 $\boldsymbol{T}$，$\boldsymbol{T}^k \to \boldsymbol{0}$ 当且仅当 $\rho(\boldsymbol{T})<1$。

证明　充分性：取 r 满足 $\rho(\boldsymbol{T})<r<1$。由引理 8.4，$\|\boldsymbol{T}^k\|_2 \le C_r r^k$，右端是公比小于 1 的几何数列，趋于零，所以 $\boldsymbol{T}^k\to\boldsymbol{0}$。

必要性：设有特征值 $|\lambda|\ge 1$，要找出一个不趋于零的轨迹。若 $\boldsymbol{T}^k\to\boldsymbol{0}$，则对任一固定向量 $\boldsymbol{v}$，$\|\boldsymbol{T}^k\boldsymbol{v}\|_2 \le \|\boldsymbol{T}^k\|_2\|\boldsymbol{v}\|_2 \to 0$。若 λ 为实数，取其特征向量 $\boldsymbol{v}$，则 $\|\boldsymbol{T}^k\boldsymbol{v}\|_2 = |\lambda|^k\|\boldsymbol{v}\|_2 \ge \|\boldsymbol{v}\|_2$，不趋于零。若 λ 非实，取第 4.4节中对应的二维实不变子空间的基 $\boldsymbol{u},\boldsymbol{w}$，排成列满秩矩阵 $\boldsymbol{P}=[\boldsymbol{u}\ \boldsymbol{w}]$；按该节，$\boldsymbol{T}^k\boldsymbol{P} = \boldsymbol{P}|\lambda|^k\boldsymbol{R}^k$，$\boldsymbol{R}$ 为旋转矩阵。取 $\boldsymbol{P}$ 的左逆 $\boldsymbol{L}=(\boldsymbol{P}^{\top}\boldsymbol{P})^{-1}\boldsymbol{P}^{\top}$，则 $\boldsymbol{L}\boldsymbol{T}^k\boldsymbol{u} = |\lambda|^k\boldsymbol{R}^k\boldsymbol{e}_1$，其长度为 $|\lambda|^k$，所以

$$\|\boldsymbol{T}^k\boldsymbol{u}\|_2 \ge \frac{|\lambda|^k}{\|\boldsymbol{L}\|_2} \ge \frac{1}{\|\boldsymbol{L}\|_2} > 0,$$

同样不趋于零。两种情形都有 $\boldsymbol{T}^k \not\to \boldsymbol{0}$。 ■

结合引理 8.3，所有初值差异都会消失，当且仅当 $\rho(\boldsymbol{T})<1$。判据要求的是全体初值，下面两个例子分别说明，检查一个初始差，或只检查每条轨迹各自收敛，都不足以代替它。

示例 8.7　反例：一个初始差衰减不能说明全部衰减　取 $\boldsymbol{T} = \operatorname{diag}(1/2, 2)$，比较两个初始差的演化：

$$\boldsymbol{T}^k \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 2^{-k} \\ 0 \end{bmatrix} \to \boldsymbol{0}$$
$$\boldsymbol{T}^k \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 2^k \end{bmatrix},$$

后者的长度为 $2^k \to \infty$。初始差 $(1,0)^{\mathsf{T}}$ 恰好不含增长方向 $\boldsymbol{e}_2$ 的分量，所以差异消失；初始差 $(0,1)^{\mathsf{T}}$ 则沿 $\boldsymbol{e}_2$ 被不断放大。这里 $\rho(\boldsymbol{T}) = 2 > 1$，判据并不成立。可见只检查某个特殊的初始差，可能恰好避开了增长方向，不能据此断言 $\boldsymbol{T}^k \to \boldsymbol{0}$。

示例 8.8　反例：各轨迹收敛但极限不同　取 $\boldsymbol{T} = \operatorname{diag}(1, 1/2)$、$\boldsymbol{c} = \boldsymbol{0}$。对任意初值，

$$\boldsymbol{x}_k = \boldsymbol{T}^k \boldsymbol{x}_0 = \begin{bmatrix} x_{0,1} \\ 2^{-k} x_{0,2} \end{bmatrix} \to \begin{bmatrix} x_{0,1} \\ 0 \end{bmatrix}.$$

每条轨迹都有极限，但极限保留了初值的第一个坐标：特征值 1 的方向上，初值既不衰减也不增长，一直被记住。所以不同初值趋于不同的点。这里 $\rho(\boldsymbol{T}) = 1$，$\boldsymbol{T}^k \to \operatorname{diag}(1, 0) \neq \boldsymbol{0}$。各轨迹分别收敛，并不等于它们趋于同一极限；后者才要求 $\boldsymbol{T}^k \to \boldsymbol{0}$。

$\rho(\boldsymbol{T}) = 1$ 时，由定理 8.6，$\boldsymbol{T}^k \not\to \boldsymbol{0}$，再由引理 8.3，初值差异不会全部消失；但不同矩阵的轨迹表现不同，下面看几个例子。仍取 $\boldsymbol{c} = \boldsymbol{0}$。$\boldsymbol{T} = \boldsymbol{I}$ 时 $\boldsymbol{x}_k = \boldsymbol{x}_0$，每条轨迹恒定，有界且收敛，但极限就是初值本身；$\boldsymbol{T} = -\boldsymbol{I}$ 时 $\boldsymbol{x}_k = (-1)^k \boldsymbol{x}_0$，非零初值的轨迹来回翻转，有界而不收敛。

平面上的 90° 旋转 $\boldsymbol{R} = \left[\begin{smallmatrix} 0 & -1 \\ 1 & 0 \end{smallmatrix}\right]$ 的特征值为 $\pm\mathrm{i}$，谱半径为 1；它保持长度，$\|\boldsymbol{R}^k \boldsymbol{x}_0\|_2 = \|\boldsymbol{x}_0\|_2$，又 $\boldsymbol{R}^4 = \boldsymbol{I}$ 而 $\boldsymbol{R}\boldsymbol{x}_0 \neq \boldsymbol{x}_0$（$\boldsymbol{x}_0 \neq \boldsymbol{0}$），所以非零初值的轨迹以 4 步为周期循环，有界而不收敛。下例说明，特征向量不够时还会出现增长。

示例 8.9　反例：谱半径为 1 而矩阵幂无界　考虑

$$\boldsymbol{J}_1 = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}.$$

它只有特征值 1，$\rho(\boldsymbol{J}_1)=1$，特征向量却只有 $(1,0)^{\top}$ 的倍数。按示例 4.16的二项式展开，把 0.8 换成 1，得

$$\boldsymbol{J}_1^{k}=(\boldsymbol{I}+\boldsymbol{N})^{k}=\boldsymbol{I}+k\boldsymbol{N}=\begin{bmatrix}1 & k\\ 0 & 1\end{bmatrix}.$$

对角元始终是 1，与谱半径相符；增长全在右上角，它随 k 线性变大，$\|\boldsymbol{J}_1^{k}\|_2\ge k\to\infty$。与 $\boldsymbol{I}$、$-\boldsymbol{I}$ 和旋转相比，缺少的正是第二条特征方向。所以谱半径等于 1 不能保证矩阵幂有界。

这种多项式因子来自对角线上方的耦合。考虑 s 阶矩阵 $\boldsymbol{J}=\lambda\boldsymbol{I}+\boldsymbol{N}$，其中 $\boldsymbol{N}$ 是超对角元为 1、其余元素为零的矩阵，满足 $\boldsymbol{N}^{s}=\boldsymbol{0}$；这样的矩阵称为 Jordan 块，上例是 $\lambda=1$、$s=2$ 的情形。本节只用这一具体形式，不需要一般的 Jordan 理论。$\lambda\boldsymbol{I}$ 与 $\boldsymbol{N}$ 可交换，二项式展开成立，且 $j\ge s$ 的项为零：

$$\boldsymbol{J}^{k}=\sum_{j=0}^{\min(k,\,s-1)}\binom{k}{j}\lambda^{k-j}\boldsymbol{N}^{j}. \tag{8.1}$$

由这个展开可以读出块幂何时有界。其中 $\binom{k}{j}\le k^{j}$，$j\le s-1$。当 $s\ge 2$、$|\lambda|=1$ 时，$\boldsymbol{J}^{k}$ 的 $(1,2)$ 元为 $k\lambda^{k-1}$，模为 $k\to\infty$，矩阵幂无界。当 $|\lambda|<1$ 时块幂仍趋于零：$\lambda=0$ 时 $\boldsymbol{J}^{k}=\boldsymbol{N}^{k}$ 在 $k\ge s$ 时为零；$0<|\lambda|<1$ 时，$\boldsymbol{J}^{k}$ 的非零元为 $\binom{k}{j}\lambda^{k-j}$，模不超过 $|\lambda|^{-j}a_k$，其中 $a_k=k^{j}|\lambda|^{k}$。相邻两项之比 $a_{k+1}/a_k=(1+1/k)^{j}|\lambda|\to|\lambda|<1$；取 q 满足 $|\lambda|<q<1$，则 k 充分大后 $a_{k+1}\le qa_k$，a_k 被一个公比为 q 的几何数列控制，趋于零。不过多项式因子可能使块幂在衰减之前先上升。把上例的特征值从 1 降到 0.8，就能看到这种先升后降。

示例 8.10　Jordan 块幂的先升后降　从初值 $(0,1)^{\top}$ 出发反复作用

$$\boldsymbol{J}=\begin{bmatrix}0.8 & 1\\ 0 & 0.8\end{bmatrix}.$$

由示例 4.16，

$$\boldsymbol{J}^{k}\begin{bmatrix}0\\ 1\end{bmatrix}=\begin{bmatrix}k\,0.8^{k-1}\\ 0.8^{k}\end{bmatrix}.$$

第二坐标按 0.8^{k} 单调衰减；第一坐标在 $k=1,2,\dots,6$ 时依次为 1、1.6、1.92、2.048、2.048、1.966（末项保留三位小数），在 $k=4,5$ 时达到最大值约 2.05，此后才衰减。这与示例 4.16中相邻项之比 $0.8(k+1)/k$ 在 $k=4$ 处等于 1 相符。特征值 $0.8<1$ 保证最终衰减，但在开始几

步，多项式因子 k 的增长胜过 0.8^{k-1} 的衰减，使第一坐标先上升到初值长度的两倍以上。

图 8.1画出这条轨迹的两个坐标。多项式因子也会抬高引理 8.4中的常数 C_r。以贯穿例为例，任何对所有 k 满足 $\|\boldsymbol{T}^k\|_2 \le C_r r^k$ 的常数，都要满足 $C_r \ge k2^{1-k}/r^k$ 对每个 k 成立（示例 8.5）；固定 k 令 $r \downarrow 1/2$，右端趋于 $2k$。所以 r 越接近 $\rho(\boldsymbol{T})$，可用的常数就必须越大，且没有上界。

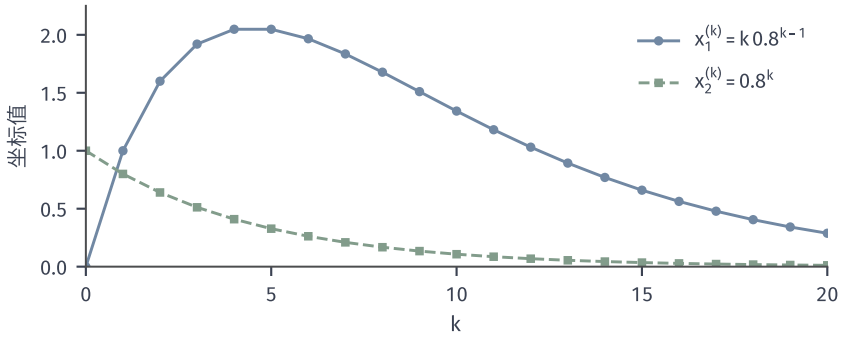


图 8.1　Jordan 块的累积项。取正文 $\boldsymbol{J} = \left[\begin{smallmatrix} 0.8 & 1 \\ 0 & 0.8 \end{smallmatrix}\right]$ 与初值 $(0,1)^{\top}$。绿线为 0.8^k，蓝线在 $k \ge 1$ 时为 $k0.8^{k-1}$，在 $k = 0$ 时为 0。点表示整数步，连线仅引导读图；两坐标最终都趋零。

$\rho(\boldsymbol{T}) > 1$ 时，由定理 8.6必要性的证明，从模大于 1 的特征值的特征方向（或不变平面）出发的初始差不会消失；但如示例 8.7所示，仍可能有特殊初值的差异趋于零。

8.3　固定输入下的平衡与收敛

初值的影响由 $\boldsymbol{T}^k$ 决定，现在回到展开式中的输入累积。若所有轨迹趋于同一个点 $\boldsymbol{x}_\star$，在更新规则两边取极限（矩阵乘法是连续的线性作用），它必须满足平衡方程

$$\boldsymbol{x}_\star = \boldsymbol{T}\boldsymbol{x}_\star + \boldsymbol{c}, \quad \text{即} \quad (\boldsymbol{I} - \boldsymbol{T})\boldsymbol{x}_\star = \boldsymbol{c}.$$

满足这个方程的点称为更新的平衡点：从它出发，更新不再改变状态。下面的定理说明平衡何时存在唯一，以及何时吸引所有初值。

定理 8.11　共同极限的判据　对固定的 $\boldsymbol{T}$ 与 $\boldsymbol{c}$，从任意初值出发的轨迹都收敛到同一个向量，当且仅当 $\rho(\boldsymbol{T}) < 1$。此时 $\boldsymbol{I} - \boldsymbol{T}$ 可逆，共同极限为 $\boldsymbol{x}_\star = (\boldsymbol{I} - \boldsymbol{T})^{-1}\boldsymbol{c}$，且

$$\boldsymbol{x}_k - \boldsymbol{x}_\star = \boldsymbol{T}^k(\boldsymbol{x}_0 - \boldsymbol{x}_\star).$$

证明 设 $\rho(\boldsymbol{T})<1$。1 的模不小于 1，不是 $\boldsymbol{T}$ 的特征值，所以 $\det(\boldsymbol{I}-\boldsymbol{T})\neq 0$，$\boldsymbol{I}-\boldsymbol{T}$ 可逆，平衡方程有唯一解 $\boldsymbol{x}_\star=(\boldsymbol{I}-\boldsymbol{T})^{-1}\boldsymbol{c}$。把 $\boldsymbol{x}_{k+1}=\boldsymbol{T}\boldsymbol{x}_k+\boldsymbol{c}$ 与 $\boldsymbol{x}_\star=\boldsymbol{T}\boldsymbol{x}_\star+\boldsymbol{c}$ 相减，得 $\boldsymbol{x}_{k+1}-\boldsymbol{x}_\star=\boldsymbol{T}(\boldsymbol{x}_k-\boldsymbol{x}_\star)$，归纳即得所述等式。由定理 8.6，$\boldsymbol{T}^k\to\boldsymbol{0}$，再由引理 8.3的证明，$\boldsymbol{T}^k(\boldsymbol{x}_0-\boldsymbol{x}_\star)\to\boldsymbol{0}$，即每条轨迹都收敛到 $\boldsymbol{x}_\star$。

反过来，设所有轨迹都收敛到同一个向量 $\boldsymbol{x}$。任取两个初值，两条轨迹之差收敛到 $\boldsymbol{x}-\boldsymbol{x}=\boldsymbol{0}$。由引理 8.3，$\boldsymbol{T}^k\to\boldsymbol{0}$，再由定理 8.6，$\rho(\boldsymbol{T})<1$。 ■

单有 $\boldsymbol{I}-\boldsymbol{T}$ 可逆，只保证平衡唯一，不保证它吸引其他初值。例如 $\boldsymbol{T}=2\boldsymbol{I}$ 时 $\boldsymbol{I}-\boldsymbol{T}=-\boldsymbol{I}$ 可逆，平衡为 $\boldsymbol{x}_\star=-\boldsymbol{c}$，但 $\boldsymbol{x}_k-\boldsymbol{x}_\star=2^k(\boldsymbol{x}_0-\boldsymbol{x}_\star)$，除非从平衡出发，轨迹都远离平衡。

定理给出了平衡的位置，但没有说明它怎样由历次输入累积而成。回到有限展开：从 $\boldsymbol{x}_0=\boldsymbol{0}$ 出发，$\boldsymbol{x}_k=\sum_{j=0}^{k-1}\boldsymbol{T}^j\boldsymbol{c}$，正是矩阵级数 $\sum_j\boldsymbol{T}^j$ 的部分和作用在 $\boldsymbol{c}$ 上。按第 3.3.3节的定义，矩阵级数 $\sum_{j=0}^{\infty}\boldsymbol{T}^j$ 收敛，指部分和 $\boldsymbol{S}_N=\sum_{j=0}^{N}\boldsymbol{T}^j$ 作为矩阵序列收敛。对标量 a，$|a|<1$ 时几何级数 $\sum_j a^j=1/(1-a)$；矩阵情形有同样的结论。

定理 8.12　Neumann 级数与逆 若 $\rho(\boldsymbol{T})<1$，则级数 $\sum_{j=0}^{\infty}\boldsymbol{T}^j$ 绝对收敛，$\boldsymbol{I}-\boldsymbol{T}$ 可逆，且

$$(\boldsymbol{I}-\boldsymbol{T})^{-1}=\sum_{j=0}^{\infty}\boldsymbol{T}^j. \tag{8.2}$$

反之，若这个级数收敛，则 $\boldsymbol{T}^k\to\boldsymbol{0}$，从而 $\rho(\boldsymbol{T})<1$。若进一步在某个次乘性矩阵范数下 $\|\boldsymbol{T}\|\le q<1$，则截断误差满足

$$\left\|(\boldsymbol{I}-\boldsymbol{T})^{-1}-\sum_{j=0}^{N}\boldsymbol{T}^j\right\|\le\frac{q^{N+1}}{1-q}. \tag{8.3}$$

证明 先证绝对收敛。取 r 满足 $\rho(\boldsymbol{T})<r<1$，由引理 8.4，$\|\boldsymbol{T}^j\|_2\le C_r r^j$。右端是收敛的标量几何级数的通项，所以 $\sum_j\|\boldsymbol{T}^j\|_2$ 收敛。由定理 3.30，级数 $\sum_j\boldsymbol{T}^j$ 收敛，记其和为 $\boldsymbol{S}$，即 $\boldsymbol{S}_N\to\boldsymbol{S}$。

再识别级数的和。逐项相消得有限几何和恒等式

$$\boldsymbol{S}_N(\boldsymbol{I}-\boldsymbol{T})=(\boldsymbol{I}-\boldsymbol{T})\boldsymbol{S}_N=\boldsymbol{I}-\boldsymbol{T}^{N+1}.$$

令 $N \to \infty$。左端是部分和乘以固定矩阵 $\boldsymbol{I}-\boldsymbol{T}$。乘以固定矩阵是连续的线性作用（第 3.2.4节），具体地，

$$\begin{aligned}&\|\boldsymbol{S}_N(\boldsymbol{I}-\boldsymbol{T})-\boldsymbol{S}(\boldsymbol{I}-\boldsymbol{T})\|_2\\&\qquad\le \|\boldsymbol{S}_N-\boldsymbol{S}\|_2\|\boldsymbol{I}-\boldsymbol{T}\|_2\to 0,\end{aligned}$$

左乘同理，所以左端分别收敛到 $\boldsymbol{S}(\boldsymbol{I}-\boldsymbol{T})$ 与 $(\boldsymbol{I}-\boldsymbol{T})\boldsymbol{S}$；右端由定理 8.6收敛到 $\boldsymbol{I}$。极限唯一，故 $\boldsymbol{S}(\boldsymbol{I}-\boldsymbol{T})=(\boldsymbol{I}-\boldsymbol{T})\boldsymbol{S}=\boldsymbol{I}$，即 $\boldsymbol{I}-\boldsymbol{T}$ 可逆且 $(\boldsymbol{I}-\boldsymbol{T})^{-1}=\boldsymbol{S}$，这就是式 (8.2)。

反过来，若级数收敛，收敛级数的通项趋于零（第 3.3.3节）：$\boldsymbol{T}^k=\boldsymbol{S}_k-\boldsymbol{S}_{k-1}\to\boldsymbol{S}-\boldsymbol{S}=\boldsymbol{0}$。再由定理 8.6得 $\rho(\boldsymbol{T})<1$。

最后证截断界。设 $\|\boldsymbol{T}\|\le q<1$，由次乘性，$\|\boldsymbol{T}^j\|\le q^j$，所以级数在这个范数下也绝对收敛。由定理 3.30的尾和估计，

$$\left\|(\boldsymbol{I}-\boldsymbol{T})^{-1}-\boldsymbol{S}_N\right\|\le\sum_{j=N+1}^{\infty}\|\boldsymbol{T}^j\|\le\sum_{j=N+1}^{\infty}q^j=\frac{q^{N+1}}{1-q},$$

即式 (8.3)。 ■

于是 $\rho(\boldsymbol{T})<1$ 时，部分和满足 $\sum_{j\le N}\boldsymbol{T}^j\boldsymbol{c}=\boldsymbol{S}_N\boldsymbol{c}$，而 $\|\boldsymbol{S}_N\boldsymbol{c}-\boldsymbol{S}\boldsymbol{c}\|_2\le\|\boldsymbol{S}_N-\boldsymbol{S}\|_2\|\boldsymbol{c}\|_2\to 0$，所以

$$\boldsymbol{x}_\star=(\boldsymbol{I}-\boldsymbol{T})^{-1}\boldsymbol{c}=\sum_{j=0}^{\infty}\boldsymbol{T}^j\boldsymbol{c}\ :$$

平衡就是全部历次输入经各自轮数传播后的总和。矩阵级数收敛的充要条件也是 $\rho(\boldsymbol{T})<1$。但这一结论针对整个矩阵级数；仅有某一个 $\boldsymbol{c}$ 对应的向量级数 $\sum_j\boldsymbol{T}^j\boldsymbol{c}$ 收敛，推不出同样的结论。例如 $\boldsymbol{T}=\operatorname{diag}(1/2,2)$、$\boldsymbol{c}=(1,0)^{\mathsf{T}}$ 时，$\sum_j\boldsymbol{T}^j\boldsymbol{c}=(2,0)^{\mathsf{T}}$ 收敛，而 $\rho(\boldsymbol{T})=2$。

示例 8.13　贯穿例的平衡　现在可以回答示例 8.1开头留下的问题。平衡方程是上三角的，从第二个分量解起：它是 $x_{\star,2}=\frac{1}{2}x_{\star,2}+1$，得 $x_{\star,2}=2$；第一个分量是 $x_{\star,1}=\frac{1}{2}x_{\star,1}+x_{\star,2}$，得 $x_{\star,1}=4$。示例 3.31已经求出 $(\boldsymbol{I}-\boldsymbol{T})^{-1}=\left[\begin{smallmatrix}2&4\\0&2\end{smallmatrix}\right]$，用它核对：

$$\boldsymbol{x}_\star=\begin{bmatrix}2&4\\0&2\end{bmatrix}\begin{bmatrix}0\\1\end{bmatrix}=\begin{bmatrix}4\\2\end{bmatrix}.$$

也可以按级数逐项看平衡怎样累积而成：j 轮之前加入的输入如今是 $\boldsymbol{T}^j\boldsymbol{c}=2^{-j}(2j,1)^{\mathsf{T}}$；由示例 3.31中的两个标量级数 $\sum_j 2^{-j}=2$ 与

$\sum_j j\,2^{1-j}=4$，两个分量的和分别为 4 与 2，与上式一致。所以开头三步中第一个分量每步加 1 的增长不会无限持续，状态趋于 $(4,2)^{\mathsf T}$；由于 $\rho(\boldsymbol T)=1/2<1$，初值项 $\boldsymbol T^k\boldsymbol x_0$ 趋于零，从任何初值出发都得到同一个平衡。

Neumann 级数定理分开了两种条件。$\rho(\boldsymbol T)<1$ 是级数收敛的充要条件，但只给出定性的收敛；$\|\boldsymbol T\|\le q<1$ 是便于检验的充分条件，它给出可以直接计算的截断误差上界。设向量范数与它诱导的矩阵范数满足 $\|\boldsymbol T\|\le q<1$。从 $\boldsymbol x_0=\boldsymbol 0$ 出发，第 k 步只累积到 $k-1$ 次幂，$\boldsymbol x_\star-\boldsymbol x_k=\big((\boldsymbol I-\boldsymbol T)^{-1}-\boldsymbol S_{k-1}\big)\boldsymbol c$，由式 (8.3)（取 $N=k-1$）与诱导范数的定义，

$$\|\boldsymbol x_k-\boldsymbol x_\star\|\le\frac{q^k}{1-q}\|\boldsymbol c\|.$$

图 8.2用一个 2×2 例子核对矩阵尾界。

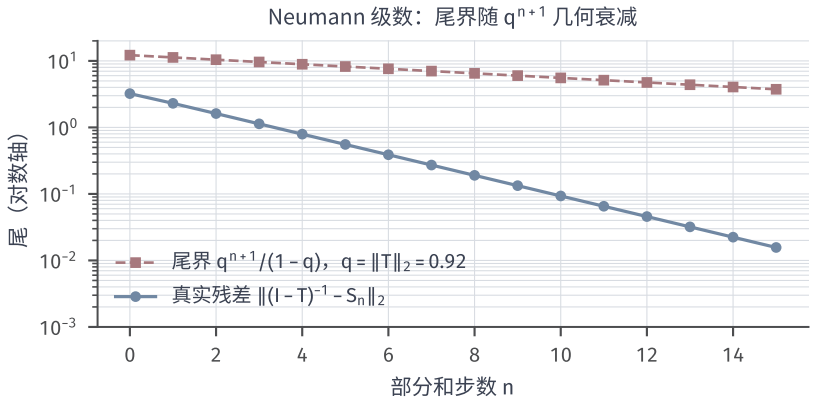


图 8.2　Neumann 级数尾界。$\boldsymbol T=[[0.7,0.6],[0,0.1]]$，$q=\|\boldsymbol T\|_2\approx0.924<1$，$(\boldsymbol I-\boldsymbol T)^{-1}=\sum\boldsymbol T^k$。蓝线为真实残差 $\|\boldsymbol R_n\|=\|\boldsymbol T^{n+1}(\boldsymbol I-\boldsymbol T)^{-1}\|$，红虚线为尾界 $q^{n+1}/(1-q)$，纵轴半对数（$n=0,\dots,15$）。

只知道 $\rho(\boldsymbol T)<1$ 时，由引理 8.4，可以取 $r<1$ 并构造坐标范数 $\|\cdot\|_*$，使 $\|\boldsymbol T\|_*\le r$，于是上面的尾界在这个范数中成立。但这个范数依赖换基矩阵 $\boldsymbol M$；回到原来的误差度量时，须保留比较常数。例如由 $\|\boldsymbol B\|_2\le\|\boldsymbol M\|_2\|\boldsymbol M^{-1}\|_2\|\boldsymbol B\|_*$，二范数下的尾界要再乘以 $\|\boldsymbol M\|_2\|\boldsymbol M^{-1}\|_2$。在贯穿例中，示例 8.5的范数给出 $q=(1+\sqrt{17})/8$ 与 $\|\boldsymbol c\|_*=4$；又 $\|\boldsymbol x\|_2\le\sqrt{x_1^2+16x_2^2}=\|\boldsymbol x\|_*$，所以 $\|\boldsymbol x_k-\boldsymbol x_\star\|_2\le4q^k/(1-q)\approx11.1\times0.641^k$。例如 $k=3$ 时真实误差 $\|(2,1/4)^{\mathsf T}\|_2\approx2.02$，上界约为 2.92。

上面的结论都要求每一轮加入同一个 $\boldsymbol{c}$。若输入随轮次变化，更新成为 $\boldsymbol{x}_{k+1}=\boldsymbol{T}\boldsymbol{x}_k+\boldsymbol{c}_k$，与引理 8.2相同的归纳给出

$$\boldsymbol{x}_k=\boldsymbol{T}^k\boldsymbol{x}_0+\sum_{j=0}^{k-1}\boldsymbol{T}^{k-1-j}\boldsymbol{c}_j.$$

这时和式中的各项不再是同一个矩阵级数作用在固定向量上，平衡方程也失去意义：一般没有一个点能同时满足每一轮的更新。

$\rho(\boldsymbol{T})<1$ 仍保证初值的影响消失，因为两条轨迹之差仍是 $\boldsymbol{T}^k(\boldsymbol{x}_0-\tilde{\boldsymbol{x}}_0)$；但它不保证轨迹本身收敛。例如 $\boldsymbol{T}=\boldsymbol{0}$ 时 $\boldsymbol{x}_k=\boldsymbol{c}_{k-1}$，轨迹完全复制输入；取 $\boldsymbol{c}_k=(-1)^k\boldsymbol{c}$（$\boldsymbol{c}\neq\boldsymbol{0}$），轨迹来回翻转，没有极限。所以逐步输入下轨迹的去向取决于输入序列本身。输入趋于固定值的情形，可以看作固定输入加上逐步误差，在第 8.5节处理。

8.4　收敛速度与短期放大

谱判据回答了能否收敛，下一个问题是接近平衡有多快。设 $\rho(\boldsymbol{T})<1$，记误差 $\boldsymbol{e}_k=\boldsymbol{x}_k-\boldsymbol{x}_\star$。由定理 8.11，$\boldsymbol{e}_k=\boldsymbol{T}^k\boldsymbol{e}_0$；取 $\rho(\boldsymbol{T})<r<1$，由引理 8.4，

$$\|\boldsymbol{e}_k\|_2\le C_r r^k\|\boldsymbol{e}_0\|_2.$$

误差至少按略大于谱半径的公比几何衰减。这是对所有初始误差一致成立的上界；某些初始方向的实际误差衰减得更快。例如在贯穿例中，$\boldsymbol{T}\boldsymbol{e}_1=\frac{1}{2}\boldsymbol{e}_1$，取 $\boldsymbol{e}_0=\boldsymbol{e}_1$ 时 $\boldsymbol{e}_k=2^{-k}\boldsymbol{e}_1$，每步恰好减半；而下面将看到，从 $\boldsymbol{e}_2$ 出发的误差长度带有因子 $2k$。谱半径只决定接近平衡的速度，平衡的位置由 $\boldsymbol{c}$ 与 $(\boldsymbol{I}-\boldsymbol{T})^{-1}$ 决定。

图 8.3显示最简单的正规情形：误差每步乘以 ρ，$\rho<1$ 时衰减，$\rho>1$ 时增长。

上界中的常数 C_r 可能大于 1，所以长期衰减不排除误差在前几步变大。贯穿例就是这样。

示例 8.14　贯穿例的暂时放大　在示例 8.1中取初值 $\boldsymbol{x}_0=\boldsymbol{x}_\star+(0,1)^{\mathsf T}=(4,3)^{\mathsf T}$，即初始误差 $\boldsymbol{e}_0=(0,1)^{\mathsf T}$，长度为 1。由 $\boldsymbol{T}^k$ 的显式式，

$$\boldsymbol{e}_k=\boldsymbol{T}^k\boldsymbol{e}_0=2^{-k}\begin{bmatrix}2k\\1\end{bmatrix}.$$

前三步的误差为 $(1,1/2)^{\mathsf T}$、$(1,1/4)^{\mathsf T}$、$(3/4,1/8)^{\mathsf T}$，长度约为 1.118、1.031、0.760。若误差每步按谱半径减半，前两步应为 0.5 与 0.25；实

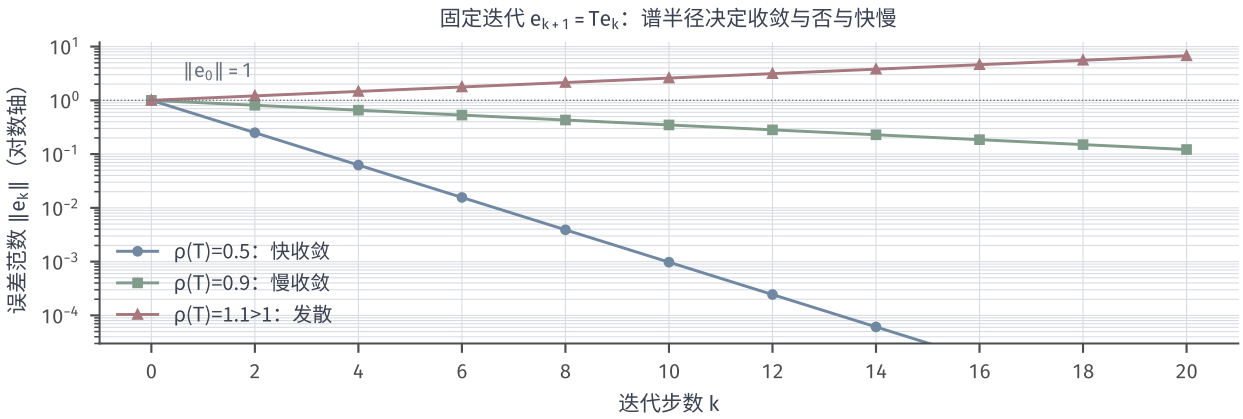


图 8.3　谱半径决定迭代的长期方向。递推 $\boldsymbol{e}^{(t+1)}=\boldsymbol{A}\boldsymbol{e}^{(t)}$、$\|\boldsymbol{e}^{(0)}\|=1$，取正规矩阵 $\boldsymbol{A}=\rho\boldsymbol{I}$ 时 $\|\boldsymbol{e}^{(t)}\|=\rho^t$：$\rho=0.5$（蓝）约十四步降到 10^{-4}，$\rho=0.9$（绿）缓慢下降，$\rho=1.1$（红）指数上升。纵轴为半对数。

> 际上前两步的误差都比初始误差还长，此后才衰减。谱半径 1/2 描述的只是长期的衰减速度。

放大来自方向之间的耦合：第二个分量的误差每步把自身传给第一个分量，在第二个分量衰减之前，第一个分量先积累起来。下面的例子耦合更强，放大也更明显。

示例 8.15　非正规矩阵的瞬态放大　换一个耦合更强的更新矩阵 $\boldsymbol{B}$，并取 $\boldsymbol{c}=\boldsymbol{0}$：

$$\begin{aligned}\boldsymbol{B}&=\begin{bmatrix}0.8 & 4\\ 0 & 0.5\end{bmatrix}\\ \boldsymbol{x}_{k+1}&=\boldsymbol{B}\boldsymbol{x}_k\\ \boldsymbol{x}_0&=(0,1)^{\mathsf{T}}.\end{aligned}\tag{8.4}$$

示例 4.13已把初值沿特征向量 $\boldsymbol{v}_1=(1,0)^{\mathsf{T}}$、$\boldsymbol{v}_2=(-40/3,1)^{\mathsf{T}}$ 分解为 $\boldsymbol{x}_0=\frac{40}{3}\boldsymbol{v}_1+\boldsymbol{v}_2$，并写出了矩阵幂与轨迹：

$$\begin{aligned}\boldsymbol{B}^k&=\begin{bmatrix}0.8^k & \frac{40}{3}(0.8^k-0.5^k)\\ 0 & 0.5^k\end{bmatrix}\\ \boldsymbol{x}_k&=\begin{bmatrix}\frac{40}{3}(0.8^k-0.5^k)\\ 0.5^k\end{bmatrix}.\end{aligned}\tag{8.5}$$

代入 $k = 1, 2, 3$ 得

$$\boldsymbol{x}_1 = \begin{bmatrix} 4 \\ 0.5 \end{bmatrix}, \quad \boldsymbol{x}_2 = \begin{bmatrix} 5.2 \\ 0.25 \end{bmatrix}, \quad \boldsymbol{x}_3 = \begin{bmatrix} 5.16 \\ 0.125 \end{bmatrix},$$

长度分别约为 4.03、5.21、5.16，都远大于初值的长度 1。另一方面 $\rho(\boldsymbol{B}) = 0.8 < 1$，由定理 8.6，轨迹最终趋于零。与贯穿例只放大约 12% 相比，这里的轨迹先放大到五倍以上、再衰减；谱半径小于 1 并不限制早期放大的幅度。

放大的原因在于初值沿特征方向的分解。$\frac{40}{3}\boldsymbol{v}_1 = (40/3, 0)^{\mathsf{T}}$ 与 $\boldsymbol{v}_2 = (-40/3, 1)^{\mathsf{T}}$ 都很长、方向几乎相反，初值 $(0, 1)^{\mathsf{T}}$ 由二者相消而成。两个分量衰减速度不同，相消很快被打破，所以长度先增后降（图 8.4）。

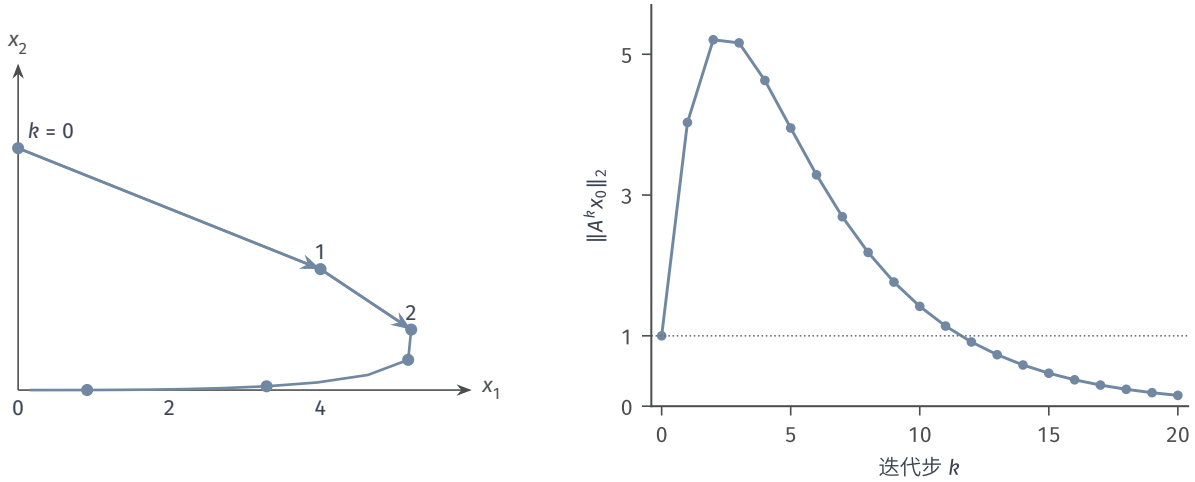


图 8.4　固定二维矩阵的反复作用。初值为 $(0, 1)^{\mathsf{T}}$，前两步的长度增加，此后回到原点；右图将长度与初始长度 1 比较。特征值 0.8 和 0.5 决定长期衰减，非正交特征方向间的相消则决定早期放大。两图使用同一个矩阵和同一组迭代点。

一般地，设 $\boldsymbol{T}$ 能用实可逆矩阵 $\boldsymbol{V}$ 对角化，$\boldsymbol{T} = \boldsymbol{V}\boldsymbol{\Lambda}\boldsymbol{V}^{-1}$，$\boldsymbol{\Lambda} = \operatorname{diag}(\lambda_1, \dots, \lambda_d)$ 为实对角矩阵。则 $\boldsymbol{T}^k = \boldsymbol{V}\boldsymbol{\Lambda}^k\boldsymbol{V}^{-1}$；又 $\|\boldsymbol{\Lambda}^k\boldsymbol{x}\|_2^2 = \sum_i \lambda_i^{2k} x_i^2 \le \rho(\boldsymbol{T})^{2k}\|\boldsymbol{x}\|_2^2$，即 $\|\boldsymbol{\Lambda}^k\|_2 \le \rho(\boldsymbol{T})^k$。由次乘性，

$$\|\boldsymbol{T}^k\|_2 \le \|\boldsymbol{V}\|_2 \|\boldsymbol{V}^{-1}\|_2 \, \rho(\boldsymbol{T})^k.$$

因子 $\|\boldsymbol{V}\|_2\|\boldsymbol{V}^{-1}\|_2$ 不小于 1，因为 $1 = \|\boldsymbol{V}\boldsymbol{V}^{-1}\|_2 \le \|\boldsymbol{V}\|_2\|\boldsymbol{V}^{-1}\|_2$；它越大，这个上界允许的早期放大越强。在示例 8.15中取 $\boldsymbol{V} = [\boldsymbol{v}_1 \ \boldsymbol{v}_2]$，两条特征方向的夹角只有约 4.3°（示例 4.27）。直接验证 $\boldsymbol{V}^{-1} = \left[\begin{smallmatrix} 1 & 40/3 \\ 0 & 1 \end{smallmatrix}\right]$，于是 $\|\boldsymbol{V}\|_2 \ge \|\boldsymbol{V}\boldsymbol{e}_2\|_2 = \|\boldsymbol{v}_2\|_2 \approx 13.37$，$\|\boldsymbol{V}^{-1}\|_2 \ge \|\boldsymbol{V}^{-1}\boldsymbol{e}_2\|_2 \approx 13.37$，乘积超过 178。

贯穿例与示例 8.10则不可对角化。以贯穿例为例，它只有特征值 $1/2$，而 $\boldsymbol{T}-\frac{1}{2}\boldsymbol{I}=\left[\begin{smallmatrix}0&1\\0&0\end{smallmatrix}\right]$ 的零空间只是 $\operatorname{span}\{\boldsymbol{e}_1\}$，凑不出两个线性无关的特征向量；两例的放大都来自式 (8.1)中的多项式因子。

正规矩阵与此相反：第 4.4节证明了 $\|\boldsymbol{T}^k\|_2=\rho(\boldsymbol{T})^k$，每一步的最大放大倍数恰为谱半径。其中幂次取 1 得 $\|\boldsymbol{T}\|_2=\rho(\boldsymbol{T})$，于是每一步都有 $\|\boldsymbol{e}_{j+1}\|_2\le\|\boldsymbol{T}\|_2\|\boldsymbol{e}_j\|_2=\rho(\boldsymbol{T})\|\boldsymbol{e}_j\|_2$，所以 $\rho(\boldsymbol{T})<1$ 时误差的长度从第一步起就不增加。所以，长期衰减、有限步内的最大放大和具体初始方向的表现要分别考察，不能只用谱半径估计中途的误差。

暂时放大说明谱半径不是单步倍率。它确切刻画的是矩阵幂的长期几何速率。

定理 8.16　Gelfand 公式　对实方阵 $\boldsymbol{T}$ 与 $d\times d$ 矩阵空间上的任意范数 $\|\cdot\|$，

$$\rho(\boldsymbol{T})=\lim_{k\to\infty}\|\boldsymbol{T}^k\|^{1/k}. \tag{8.6}$$

若该范数还满足次乘性，则 $\rho(\boldsymbol{T})\le\|\boldsymbol{T}\|$。

证明　先在二范数中证明。上界：对任意 $r>\rho(\boldsymbol{T})$，由引理 8.4，$\|\boldsymbol{T}^k\|_2^{1/k}\le C_r^{1/k}r$，而 $C_r^{1/k}\to1$，所以 $\limsup_k\|\boldsymbol{T}^k\|_2^{1/k}\le r$。

下界：取模为 $\rho(\boldsymbol{T})$ 的特征值 λ，重复定理 8.6必要性证明中的估计。若 λ 为实数，取单位特征向量 $\boldsymbol{v}$，则 $\|\boldsymbol{T}^k\|_2\ge\|\boldsymbol{T}^k\boldsymbol{v}\|_2=\rho(\boldsymbol{T})^k$。若 λ 非实，同一证明中的 $\boldsymbol{u}\neq\boldsymbol{0}$ 满足 $\|\boldsymbol{T}^k\boldsymbol{u}\|_2\ge\rho(\boldsymbol{T})^k/\|\boldsymbol{L}\|_2$，所以 $\|\boldsymbol{T}^k\|_2\ge c\,\rho(\boldsymbol{T})^k$，其中 $c=1/(\|\boldsymbol{L}\|_2\|\boldsymbol{u}\|_2)>0$ 与 k 无关。两种情形都有 $\|\boldsymbol{T}^k\|_2^{1/k}\ge c^{1/k}\rho(\boldsymbol{T})$（实特征值时 $c=1$），而 $c^{1/k}\to1$，故 $\liminf_k\|\boldsymbol{T}^k\|_2^{1/k}\ge\rho(\boldsymbol{T})$。

合起来，$\rho(\boldsymbol{T})\le\liminf_k\|\boldsymbol{T}^k\|_2^{1/k}\le\limsup_k\|\boldsymbol{T}^k\|_2^{1/k}\le r$ 对每个 $r>\rho(\boldsymbol{T})$ 成立。令 r 趋于 $\rho(\boldsymbol{T})$，上下极限相等，极限存在且等于 $\rho(\boldsymbol{T})$。

再推广到任意范数。由有限维范数等价（定理 3.27），存在与矩阵无关的常数 $0<c_1\le c_2$，使 $c_1\|\boldsymbol{B}\|_2\le\|\boldsymbol{B}\|\le c_2\|\boldsymbol{B}\|_2$ 对所有 d 阶方阵成立。取 $\boldsymbol{B}=\boldsymbol{T}^k$ 并开 k 次方，$c_1^{1/k}$ 与 $c_2^{1/k}$ 都趋于 1，由夹逼，$\|\boldsymbol{T}^k\|^{1/k}$ 与 $\|\boldsymbol{T}^k\|_2^{1/k}$ 有相同的极限。

最后，若范数满足次乘性，则 $\|\boldsymbol{T}^k\|\le\|\boldsymbol{T}\|^k$，即 $\|\boldsymbol{T}^k\|^{1/k}\le\|\boldsymbol{T}\|$ 对每个 k 成立。令 $k\to\infty$ 即得 $\rho(\boldsymbol{T})\le\|\boldsymbol{T}\|$。 ■

最后一条说明，次乘性范数小于 1 必定使谱半径小于 1，这正是本节开头的充分条件；贯穿例说明反过来不成立。Gelfand 公式说明，谱半径是矩阵幂最大放大倍数的长期几何平均。它不表示每条误差轨迹每一步都乘

以同一个倍率：某些初值可能不含最慢衰减方向，非正规作用还可能在早期放大误差。

设 $0<\rho(\boldsymbol{T})<1$。若粗略用 $\rho(\boldsymbol{T})^m$ 估计 m 步后的长期倍率，由 $\rho(\boldsymbol{T})^m = 1/10$ 得到缩小十倍的参考步数

$$m = \frac{1}{\log_{10}\bigl(1/\rho(\boldsymbol{T})\bigr)}.$$

例如 $\rho=0.5$ 时约为 3.3 步，$\rho=0.99$ 时约为 229 步：谱半径接近零时每步都显著缩小误差，接近一时缩小十倍要上百步。实际达到给定精度的步数还受常数、初始方向和暂时放大的影响。在示例 8.14中，参考步数约为 3.3，但 $\|\boldsymbol{e}_k\|_2 = 2^{-k}\sqrt{4k^2+1}$ 在 $k=1,\dots,7$ 时依次约为 1.118、1.031、0.760、0.504、0.314、0.188、0.110，到 $k=8$ 才第一次降到 0.1 以下（约为 0.063），即要 8 步才缩小十倍。精确解未知时还需要用可计算的量判断何时停止，这在第 11章联系残差讨论。

8.5　误差传播与累积

前面假设每一轮都精确执行。实际计算中，每轮可能引入新的误差，例如舍入，或者只近似地算出 $\boldsymbol{T}\boldsymbol{y}_k$。把第 k 轮附加的误差记为 $\boldsymbol{\delta}_k$，实际得到的序列满足

$$\boldsymbol{y}_{k+1} = \boldsymbol{T}\boldsymbol{y}_k + \boldsymbol{c} + \boldsymbol{\delta}_k.$$

设 $\rho(\boldsymbol{T})<1$，$\boldsymbol{x}_\star$ 为定理 8.11中的平衡，令 $\boldsymbol{e}_k = \boldsymbol{y}_k - \boldsymbol{x}_\star$。与 $\boldsymbol{x}_\star = \boldsymbol{T}\boldsymbol{x}_\star + \boldsymbol{c}$ 相减，得 $\boldsymbol{e}_{k+1} = \boldsymbol{T}\boldsymbol{e}_k + \boldsymbol{\delta}_k$。这与开头的更新形式相同，只是每轮的输入换成了 $\boldsymbol{\delta}_k$，于是可以仿照有限展开分析。

定理 8.17　逐步误差的累积　设 $\rho(\boldsymbol{T})<1$，$\boldsymbol{y}_k$ 与 $\boldsymbol{e}_k$ 如上。

1. 对每个 $k\ge 0$，
$$\boldsymbol{e}_k = \boldsymbol{T}^k\boldsymbol{e}_0 + \sum_{j=0}^{k-1}\boldsymbol{T}^{k-1-j}\boldsymbol{\delta}_j.$$
2. 取一个向量范数及其诱导的矩阵范数，若 $\|\boldsymbol{T}\|\le q<1$ 且 $\|\boldsymbol{\delta}_j\|\le\delta$ 对所有 j 成立，则
$$\|\boldsymbol{e}_k\| \le q^k\|\boldsymbol{e}_0\| + \delta\,\frac{1-q^k}{1-q}, \tag{8.7}$$
从而 $\limsup_{k\to\infty}\|\boldsymbol{e}_k\| \le \delta/(1-q)$。

3. 若只知道 $\rho(\boldsymbol{T})<1$，取 $\rho(\boldsymbol{T})<r<1$ 与引理 8.4中的常数 C_r。若 $\|\boldsymbol{\delta}_j\|_2\le\delta$ 对所有 j 成立，则

$$\|\boldsymbol{e}_k\|_2\le C_r r^k\|\boldsymbol{e}_0\|_2+C_r\delta\,\frac{1-r^k}{1-r}.$$

证明 第一条对 k 归纳。$k=0$ 时和式为空。设等式对 k 成立，则

$$\begin{aligned}\boldsymbol{e}_{k+1}&=\boldsymbol{T}\boldsymbol{e}_k+\boldsymbol{\delta}_k\\&=\boldsymbol{T}^{k+1}\boldsymbol{e}_0+\sum_{j=0}^{k-1}\boldsymbol{T}^{k-j}\boldsymbol{\delta}_j+\boldsymbol{T}^0\boldsymbol{\delta}_k,\end{aligned}$$

末两项合起来是 $\sum_{j=0}^{k}\boldsymbol{T}^{k-j}\boldsymbol{\delta}_j$，即 $k+1$ 时的等式。

第二条。由三角不等式、诱导范数的界与次乘性，$\|\boldsymbol{T}^i\boldsymbol{v}\|\le q^i\|\boldsymbol{v}\|$，所以

$$\begin{aligned}\|\boldsymbol{e}_k\|&\le q^k\|\boldsymbol{e}_0\|+\sum_{j=0}^{k-1}q^{k-1-j}\delta\\&=q^k\|\boldsymbol{e}_0\|+\delta\sum_{i=0}^{k-1}q^i,\end{aligned}$$

末项的有限几何和等于 $\delta(1-q^k)/(1-q)$，这就是式 (8.7)。右端随 $k\to\infty$ 收敛到 $\delta/(1-q)$，所以 $\|\boldsymbol{e}_k\|$ 的上极限不超过它。

第三条。把第一条的展开取二范数，用 $\|\boldsymbol{T}^i\|_2\le C_r r^i$ 代替第二条中的 q^i，同样求和即得。 ■

展开式中，第一项是初始误差的传播，按几何速度消失；和式中，j 轮的附加误差再经过 $k-1-j$ 次作用，较早的误差衰减得多，较近的误差几乎原样保留。所以持续的附加误差不会随迭代消失，式 (8.7)右端随 k 增大趋于 $\delta/(1-q)$，q 越接近 1，这个上界越大。

这是持续有界扰动下的最坏情形上界。它不是每条轨迹必然达到的误差下限：例如各轮误差都为零时，$\boldsymbol{e}_k=\boldsymbol{T}^k\boldsymbol{e}_0\to\boldsymbol{0}$，最终远小于 $\delta/(1-q)$。它也不保证误差存在极限。取 $\boldsymbol{T}=\boldsymbol{0}$、$\boldsymbol{c}=\boldsymbol{0}$，则 $\boldsymbol{x}_\star=\boldsymbol{0}$、$q=0$；再取单位向量 $\boldsymbol{u}$ 与交替变号的附加误差 $\boldsymbol{\delta}_k=(-1)^k\delta\boldsymbol{u}$，则 $\boldsymbol{e}_k=\boldsymbol{\delta}_{k-1}=(-1)^{k-1}\delta\boldsymbol{u}$ $(k\ge1)$。误差的长度始终等于上界 $\delta/(1-q)=\delta$，说明这个上界不能再改进，但 $\boldsymbol{e}_k$ 来回翻转，没有极限。

第三条中两项都带着常数 C_r：在非正规的 $\boldsymbol{T}$ 下，即使每轮附加的误差很小，它们在被衰减之前也可能先被暂时放大，累积的上界因此按 C_r 倍增大。

有界误差留下一个不消失的误差水平。若附加误差本身逐渐变小，结论会改善，下面的定理分两种情形说明。为了只用一个范数书写，取 q 满足 $\rho(\boldsymbol{T}) < q < 1$；由引理 8.4，存在坐标范数 $\|\cdot\|_*$ 使 $\|\boldsymbol{T}\|_* \le q$。若已经知道某个诱导范数满足 $\|\boldsymbol{T}\| \le q < 1$，也可以直接用它。

定理 8.18　趋零与可求和的逐步误差　设 $\rho(\boldsymbol{T}) < 1$，$\boldsymbol{e}_k$ 如上，向量范数 $\|\cdot\|$ 诱导的矩阵范数满足 $\|\boldsymbol{T}\| \le q < 1$。

1. 若 $\boldsymbol{\delta}_j \to \boldsymbol{0}$，则 $\boldsymbol{e}_k \to \boldsymbol{0}$。
2. 若 $\sum_{j=0}^{\infty} \|\boldsymbol{\delta}_j\| = D < \infty$，则对每个 k，

$$\|\boldsymbol{e}_k\| \le q^k \|\boldsymbol{e}_0\| + D,$$

并且 $\boldsymbol{e}_k \to \boldsymbol{0}$。

证明　两条都从定理 8.17第一条的展开式出发，由三角不等式与 $\|\boldsymbol{T}^i \boldsymbol{v}\| \le q^i \|\boldsymbol{v}\|$，

$$\|\boldsymbol{e}_k\| \le q^k \|\boldsymbol{e}_0\| + \sum_{j=0}^{k-1} q^{k-1-j} \|\boldsymbol{\delta}_j\|.$$

第一条。任取 $\varepsilon > 0$，由 $\boldsymbol{\delta}_j \to \boldsymbol{0}$，存在 J 使 $j \ge J$ 时 $\|\boldsymbol{\delta}_j\| \le \varepsilon$。对 $k > J$，把和式分成 $j < J$ 与 $j \ge J$ 两部分。前一部分中 $k-1-j \ge k-J$，故它不超过 $q^{k-J} \sum_{j<J} \|\boldsymbol{\delta}_j\|$；后一部分不超过 $\varepsilon \sum_{i \ge 0} q^i = \varepsilon/(1-q)$。于是

$$\|\boldsymbol{e}_k\| \le q^k \|\boldsymbol{e}_0\| + q^{k-J} \sum_{j<J} \|\boldsymbol{\delta}_j\| + \frac{\varepsilon}{1-q}.$$

J 固定后，前两项随 $k \to \infty$ 趋于零，所以 $\limsup_k \|\boldsymbol{e}_k\| \le \varepsilon/(1-q)$。$\varepsilon$ 任意，故 $\|\boldsymbol{e}_k\| \to 0$，由有限维范数等价即 $\boldsymbol{e}_k \to \boldsymbol{0}$。

第二条。$q^{k-1-j} \le 1$，所以和式不超过 $\sum_j \|\boldsymbol{\delta}_j\| = D$，即得上界。收敛级数的通项趋于零，所以 $\|\boldsymbol{\delta}_j\| \to 0$，由第一条得 $\boldsymbol{e}_k \to \boldsymbol{0}$。 ∎

三种误差的差别在于每个误差被计入几次。有界误差每轮都重新加入，它们的贡献叠加成 $\delta(1 + q + q^2 + \cdots)$，最终水平可达 $\delta/(1-q)$，q 越接近 1 越高。趋零的误差最终也被消除，但误差不会比附加误差本身衰减得更快：例如 $\boldsymbol{T} = \boldsymbol{0}$ 时 $\boldsymbol{e}_{k+1} = \boldsymbol{\delta}_k$。可求和的误差总量有限，每个误差进入后只会被衰减，所以累积误差不超过总量 D，不再带因子 $1/(1-q)$。

第 8.3节末尾提出的逐步输入正是第一种情形的应用。若 $\boldsymbol{c}_k \to \boldsymbol{c}$，令 $\boldsymbol{\delta}_k = \boldsymbol{c}_k - \boldsymbol{c}$，则 $\boldsymbol{x}_{k+1} = \boldsymbol{T}\boldsymbol{x}_k + \boldsymbol{c} + \boldsymbol{\delta}_k$，而 $\boldsymbol{\delta}_k \to \boldsymbol{0}$，所以轨迹仍收敛到固定输入 $\boldsymbol{c}$ 的平衡 $(\boldsymbol{I} - \boldsymbol{T})^{-1}\boldsymbol{c}$。

本章假设 $\boldsymbol{T}$ 固定；具体算法如何产生附加误差、怎样选择更新规则和参数、何时停止计算，留给第 11章处理。

8.6 本章小结

本章开头问：反复执行 $\boldsymbol{x}_{k+1} = \boldsymbol{T}\boldsymbol{x}_k + \boldsymbol{c}$ 时，状态能否从任意初值趋于同一个平衡，接近得多快，每步的小误差又会累积到多大？展开递推得到 $\boldsymbol{x}_k = \boldsymbol{T}^k\boldsymbol{x}_0 + \sum_{j<k}\boldsymbol{T}^j\boldsymbol{c}$，三个问题都化为矩阵幂 $\boldsymbol{T}^k$ 的行为。

初值的影响全部消失，当且仅当 $\boldsymbol{T}^k \to \boldsymbol{0}$，当且仅当 $\rho(\boldsymbol{T}) < 1$。证明的关键是：对任意 $r > \rho(\boldsymbol{T})$，由实 Schur 形构造一个坐标范数，使 $\boldsymbol{T}$ 在其中每步至多放大 r 倍，从而 $\|\boldsymbol{T}^k\|_2 \le C_r r^k$。范数小于 1 是便于检验的充分条件，但不是必要条件。$\rho(\boldsymbol{T}) = 1$ 时，轨迹可能恒定、振荡、循环或无界增长，取决于是否缺少特征向量。

在同一条件 $\rho(\boldsymbol{T}) < 1$ 下，Neumann 级数 $\sum_j \boldsymbol{T}^j$ 收敛到 $(\boldsymbol{I}-\boldsymbol{T})^{-1}$，所有初值趋于同一个平衡 $\boldsymbol{x}_\star = (\boldsymbol{I}-\boldsymbol{T})^{-1}\boldsymbol{c} = \sum_j \boldsymbol{T}^j\boldsymbol{c}$，即历次输入经各自轮数传播后的总和。$\boldsymbol{I}-\boldsymbol{T}$ 可逆只保证平衡唯一，不保证它吸引其他初值；输入随轮次变化时，$\rho(\boldsymbol{T}) < 1$ 只保证初值影响消失，轨迹的去向还取决于输入序列。

谱半径决定长期的几何速度：Gelfand 公式 $\rho(\boldsymbol{T}) = \lim_k \|\boldsymbol{T}^k\|^{1/k}$，粗略地每 $1/\log_{10}(1/\rho)$ 步缩小十倍。它不是单步倍率。正规矩阵每步的放大恰为谱半径，误差从第一步起不增加；非正规矩阵的常数 C_r 可能远大于 1，误差会先放大、再衰减，放大来自非正交特征方向的相消或 Jordan 块中的多项式因子。

每步附加的误差 $\boldsymbol{\delta}_k$ 按 $\boldsymbol{T}^{k-1-j}$ 传播后叠加。有界误差留下至多 $\delta/(1-q)$ 的误差水平，它不随迭代消失；趋零的误差最终被消除；可求和的误差累积不超过其总量。非正规时这些上界还要乘以 C_r。

因此，判断一个固定递推能否使用，要分别看三件事：谱半径是否小于一（能否收敛），常数与暂时放大有多大（中途误差会不会失控），每步误差属于哪一类（最终精度能达到多少）。第 11章由线性方程构造具体的更新矩阵，并结合残差决定何时停止；初值和输入随连续时间变化的线性系统，则在卷六第 2 章“线性微分方程与系统”研究，那里矩阵幂换成矩阵指数。

第三部分

线性方程与优化

Linear Equations and Optimization

阅读指引

前两部分大多做正向计算：给定矩阵和输入，用乘法算出输出，再用谱与奇异值看清这个作用。本部分处理反向的问题：矩阵和希望得到的输出已经给定，要找出输入向量，或者在结构约束下找出一张矩阵。所用工具都已建立，包括第一部分的列空间、零空间、秩与正交投影，第二部分的谱分解、奇异值分解、极分解、条件数和矩阵幂；本部分不依赖多元微分或一般优化理论。

第 9—14 章研究线性方程 $\boldsymbol{Ax} = \boldsymbol{b}$，依次回答四个问题。第 9 章先确定要求什么样的解：方程相容时保留全部精确解，不相容时改求最小二乘解，解不唯一时取最小范数代表，伪逆把这些情形写成同一个公式，并给出核对每种目标的条件。

第 10—13 章讲怎样把选定的解算出来：直接法用 LU、Cholesky、分块 LDL、QR 与 SVD 等分解在有限步内求解；定常迭代用易解的分裂矩阵反复修正；Krylov 子空间法在逐步扩大的子空间中按不同残差准则选取近似；行列投影法每步只读一行或一列。这几章的每个算法都按主要思想、算法实现与算法分析展开，用原始数据核验输出。

第 14 章回答算出的结果能相信多少：区分问题本身的敏感性、有限精度的算法误差与提前停止的误差，用正则化或谱截断主动改变目标，并在同一目标和精度下比较各方法的总成本。

第 15、16 章把未知量换成矩阵。矩阵逼近一章在秩或正交约束下寻找离给定矩阵最近的矩阵，由 Rayleigh 商与迹极值得到截断 SVD 的最优性，再讨论加权逼近、正交逼近与旋转约束。矩阵方程一章研究同时受左乘和右乘的 Sylvester 方程与它的对称特例 Lyapunov 方程，给出谱条件、基于 Schur 分解的求解，以及离散型方程的级数解与正定性；连续型正定解的积分证明留给后续演化理论。

阅读时要注意区分几组容易混淆的对象：原残差为零、正规残差为零与解落在行空间，分别对应精确解、最小二乘与最小范数三种不同的验收条件；拟合值唯一与系数唯一；算法的迭代步数与达到同一精度的总成本；问题病态与算法不稳定；正则化改变了所求的问题，而不是把原问题解得更准；第 14 章为稳定求解而截断取逆，第 15 章则把截断矩阵本身作为近似对象。

第 9 章

线性方程与最小二乘的选解

前几章的计算大多是正向的：给定矩阵和输入，用乘法算出输出。实际问题常常反过来：矩阵和希望得到的输出已经给定，要找出输入。例如在三个时刻观测一个按直线变化的量，要由观测值反推直线的截距和斜率。三条观测可能恰好落在一条直线上，可能互相矛盾，也可能因为模型里有重复的参数而对应无穷多组系数。于是首先要回答：对方程 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$，在每种情况下究竟要求什么样的解。

本章用列空间和零空间回答这个问题。第 9.1节判断方程是否有解、有几个解；无解时，第 9.2节改求离 $\boldsymbol{b}$ 最近的可实现输出，即最小二乘解；解不唯一时，第 9.3节取欧氏范数最小的一个作代表。有限维的最小二乘问题总有解，其最小范数代表也总是唯一的，所以第 9.4节能用奇异值分解与伪逆把各种情形写成同一个公式。随后两节说明加权与齐次两种变形各自改变了目标的哪一部分，最后一节把各种目标写成可以核对的条件。

所需工具都已建立：列空间、零空间、秩与秩零度定理见第 2章，正交分解、正交投影与 Gram 因子见第 3章，奇异值分解见第 5章。最小二乘与最小范数的结论都由正交分解和代数恒等式得到，不需要多元微分或一般优化理论。本章只讨论目标的定义、存在唯一性与最优性，不安排算法；怎样把选定的解算出来，从第 10章开始讨论。

本部分讨论线性方程的各章沿用以下记号。已知量为 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$ 与 $\boldsymbol{b} \in \mathbb{R}^{m}$，未知量为 $\boldsymbol{x} \in \mathbb{R}^{d}$，方阵情形取 $m = d$。精确解或选定的最小范数解记作 $\boldsymbol{x}_{\star}$，最小二乘解记作 $\hat{\boldsymbol{x}}$，迭代近似记作 $\boldsymbol{x}_{k}$，残差记作 $\boldsymbol{r}_{k} = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_{k}$。若干右端排成 $\boldsymbol{B} = [\boldsymbol{b}_{1} \ \cdots \ \boldsymbol{b}_{s}]$ 时，方程写成 $\boldsymbol{A}\boldsymbol{X} = \boldsymbol{B}$，各列分别求解，并尽量共用对 $\boldsymbol{A}$ 的分解。

求解过程统一以 $\boldsymbol{A}$、$\boldsymbol{b}$ 为输入、以 $\boldsymbol{x}$ 为输出。初值、容差、步数上限、松弛参数、权矩阵和预条件等是各方法自己的参数；分解因子、残差、子空间坐标和搜索方向是计算中的中间量，最后都要换回原变量 $\boldsymbol{x}$。以矩阵为

未知量的 Sylvester 方程有左右两个系数矩阵，它们的角色在第 16章引入时再说明。

9.1　方程的相容性与解集

给定 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$ 与 $\boldsymbol{b} \in \mathbb{R}^{m}$，记 $\boldsymbol{a}_1, \dots, \boldsymbol{a}_d$ 为 $\boldsymbol{A}$ 的各列。由 $\boldsymbol{A}\boldsymbol{x} = x_1\boldsymbol{a}_1 + \cdots + x_d\boldsymbol{a}_d$，方程 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 问的是两件事：能否用 $\boldsymbol{A}$ 的列组合出 $\boldsymbol{b}$，以及组合系数是什么。输出 $\boldsymbol{A}\boldsymbol{x}$ 取遍列空间 $\operatorname{range}(\boldsymbol{A})$，所以方程有解当且仅当 $\boldsymbol{b} \in \operatorname{range}(\boldsymbol{A})$，这时称方程**相容**（consistent）。

这个条件可以用秩来检验。把 $\boldsymbol{b}$ 并到 $\boldsymbol{A}$ 右侧得到增广矩阵 $[\boldsymbol{A}\ \boldsymbol{b}]$：若 $\boldsymbol{b}$ 已是各列的组合，添上它不扩大列张成的空间，秩不变；否则 $\boldsymbol{b}$ 带来一个新方向，秩恰好加一。因此

$$\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b} \text{ 相容} \iff \operatorname{rank}[\boldsymbol{A}\ \boldsymbol{b}] = \operatorname{rank}\boldsymbol{A}. \tag{9.1}$$

判据只涉及 $\boldsymbol{b}$ 与列空间的关系，方程个数与未知量个数本身不能决定方程是否相容。例如两个方程 $x = 1$、$x = 1$ 多于未知量，却有唯一解；方程 $x_1 + x_2 = 1$、$x_1 + x_2 = 2$ 的个数与未知量个数相同，却无解。

方程相容以后，解有几个由零空间决定：两个解之差属于 $\ker\boldsymbol{A}$，零空间中的向量加到任何解上也不改变输出。把有没有解和有几个解合起来，得到下面的三分法。

定理 9.1　线性方程的三种情况　设 $r = \operatorname{rank}\boldsymbol{A}$，$\tilde{r} = \operatorname{rank}[\boldsymbol{A}\ \boldsymbol{b}]$。则恰有下面一种情况成立：$\tilde{r} = r = d$ 时方程有唯一解；$\tilde{r} = r < d$ 时有无穷多解；$\tilde{r} > r$ 时无解。

证明　添上一列至多增加一个方向，所以 $\tilde{r} \in \{r, r+1\}$，三个条件互斥且穷尽。由式 (9.1)，$\tilde{r} > r$ 当且仅当无解。相容时任取一个解 $\boldsymbol{x}_0$，全部解为 $\boldsymbol{x}_0 + \ker\boldsymbol{A}$；由秩零度定理 2.26，$\dim\ker\boldsymbol{A} = d - r$，故 $r = d$ 时解唯一，$r < d$ 时沿任一非零核向量 $\boldsymbol{n}$ 平移得到无穷多个解 $\boldsymbol{x}_0 + t\boldsymbol{n}$。 ∎

第 2章的满列秩 $r = d$ 与满行秩 $r = m$ 在这里保证的是不同的事情。满列秩保证至多一个精确解，但不保证有解：$\boldsymbol{A} = (1,1)^{\mathsf{T}}$ 满列秩，只有两个分量相等的 $\boldsymbol{b}$ 才相容。满行秩时列空间是整个 $\mathbb{R}^m$，每个右端都有精确解，但解可能不唯一：$\boldsymbol{A} = (1,1)$ 满行秩，$x_1 + x_2 = b$ 的解可沿 $(1,-1)^{\mathsf{T}}$ 任意

平移。方阵满秩时两种保证同时成立，对每个右端恰有一解，这正是 $\boldsymbol{A}$ 可逆的情形。对 d 阶方阵，可逆性也可以由行列式判断：

$$\boldsymbol{A}\text{ 可逆} \iff \det \boldsymbol{A} \neq 0,$$
$$\boldsymbol{A}^{-1} = \frac{1}{\det \boldsymbol{A}} \operatorname{adj}(\boldsymbol{A}).$$

若 $\boldsymbol{A}$ 可逆，由行列式的乘法性（第 1.3.1节）得 $\det \boldsymbol{A} \det(\boldsymbol{A}^{-1}) = 1$，故 $\det \boldsymbol{A} \neq 0$；反过来，把古典伴随恒等式 $\boldsymbol{A}\operatorname{adj}(\boldsymbol{A}) = \operatorname{adj}(\boldsymbol{A})\boldsymbol{A} = (\det \boldsymbol{A})\boldsymbol{I}$（定理 1.31）除以 $\det \boldsymbol{A}$，就得到逆矩阵。行列式适合作理论判据；实际计算不展开它，第 10.1节的消元在求解的同时就能读出秩。

下面用同一个拟合问题依次产生三种情况，本章后面还会回到它。

示例 9.2　直线观测中的三种情况　设某个量随时间按 $a + st$ 线性变化，我们在 $t = 0, 1, 2$ 三个时刻各观测一次，想由观测反推截距 a 与斜率 s。未知量为 $\boldsymbol{x} = (a, s)^{\mathsf{T}}$，系数矩阵

$$\boldsymbol{A} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}$$

的第一列对应常数项，第二列是观测时刻。若观测为 $\boldsymbol{b} = (1, 2, 3)^{\mathsf{T}}$，前两个方程给出 $a = s = 1$，第三个方程 $a + 2s = 3$ 也成立；$\boldsymbol{A}$ 满列秩，所以 $(1, 1)^{\mathsf{T}}$ 是唯一解。

如果模型中有两个参数起同样的作用，解就不再唯一。把常数列重复一次作为第三列，得到 $\widetilde{\boldsymbol{A}} = [\boldsymbol{a}_1\ \boldsymbol{a}_2\ \boldsymbol{a}_1]$，方程成为 $(x_1 + x_3) + x_2 t_i = b_i$。对同一个 $\boldsymbol{b}$，三个方程只要求 $x_1 + x_3 = 1$、$x_2 = 1$，两个常数系数怎样分配都可以；秩为 $2 < 3$，有无穷多解。

反过来，保留原来两列，而把第三次观测改为 2，即 $\boldsymbol{b} = (1, 2, 2)^{\mathsf{T}}$。前两个方程仍给出 $a = s = 1$，代入第三个方程却得到 $3 = 2$。用秩来表述，$\det[\boldsymbol{A}\ \boldsymbol{b}] = -1 \neq 0$，增广矩阵的秩 $\tilde{r} = 3$ 大于 $r = 2$，三条等式不能同时满足。第 9.2节用最小二乘处理这种情况。

对两种相容情形，给定一个特解 $\boldsymbol{x}_p$，由任意两解之差属于 $\ker \boldsymbol{A}$，全部解为

$$\boldsymbol{x}_p + \ker \boldsymbol{A} = \{\boldsymbol{x}_p + \boldsymbol{n} : \boldsymbol{n} \in \ker \boldsymbol{A}\}, \tag{9.2}$$

它是把子空间 $\ker \boldsymbol{A}$ 平移到 $\boldsymbol{x}_p$ 处得到的**仿射空间**（affine space），自由度为 $d - r$。核为零时它退化为唯一解，核非零时给出一整个仿射解集。图 9.1以 $\boldsymbol{A} = (1, 1)$ 画出这种结构。

复制常数列的例子中，令 $x_3 = 0$ 得特解 $(1,1,0)^{\top}$；零空间要求 $n_1+n_3=0$、$n_2=0$，由 $(1,0,-1)^{\top}$ 张成，所以全部解为 $\boldsymbol{x} = (1+t,1,-t)^{\top}$，$t \in \mathbb{R}$。逐项代回，$\tilde{\boldsymbol{A}}\boldsymbol{x}$ 的三个分量是 $(1+t)-t=1$、$(1+t)+1-t=2$、$(1+t)+2-t=3$，对每个 t 都等于 $\boldsymbol{b}$。唯一的自由参数 t 正对应常数项在两个相同列之间的拆法。这里只建立解集的结构，第 10章的消元与分解把它变成计算过程。

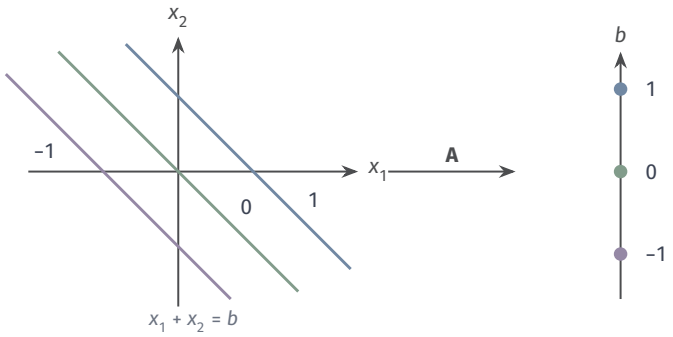


图 9.1　同一输出对应的整组输入。对 $\boldsymbol{A} = (1,1)$，蓝、绿、紫直线分别满足 $x_1 + x_2 = 1, 0, -1$；右侧同色点是各直线的输出。绿色直线是 $\ker \boldsymbol{A}$，其余直线是它的平移。把一整条直线归为一类后，才得到与可达输出的一一对应。

9.2 最小二乘解

当 $\boldsymbol{b}$ 不在列空间中时，没有输入能精确产生它。这时改求使输出误差最小的系数：

$$\min_{\boldsymbol{x}\in\mathbb{R}^d} \|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|_2^2, \tag{9.3}$$

称为**最小二乘**（least squares）问题。问题中有三个对象：系数 $\boldsymbol{x}$、拟合值 $\boldsymbol{A}\boldsymbol{x}$ 和残差 $\boldsymbol{r} = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}$。目标只通过拟合值依赖系数，而拟合值取遍列空间，所以可以先不管系数，求列空间中离 $\boldsymbol{b}$ 最近的点，这是**子空间最近点**问题。

由正交分解（引理 3.58），$\boldsymbol{b}$ 唯一地写成 $\hat{\boldsymbol{b}} + \boldsymbol{e}$，其中 $\hat{\boldsymbol{b}} \in \operatorname{range}(\boldsymbol{A})$，$\boldsymbol{e} \perp \operatorname{range}(\boldsymbol{A})$。对列空间中任一点 $\boldsymbol{u}$，$\hat{\boldsymbol{b}} - \boldsymbol{u}$ 仍在列空间中，因而与 $\boldsymbol{e}$ 正交，勾股关系给出

$$\|\boldsymbol{b} - \boldsymbol{u}\|_2^2 = \|\hat{\boldsymbol{b}} - \boldsymbol{u}\|_2^2 + \|\boldsymbol{e}\|_2^2 \geq \|\boldsymbol{e}\|_2^2, \tag{9.4}$$

等号当且仅当 $\boldsymbol{u} = \hat{\boldsymbol{b}}$。所以正交投影 $\hat{\boldsymbol{b}}$ 是唯一的最优拟合值，最近点也由“残差与列空间正交”完全刻画。图 9.2在一条直线子空间上画出这一几何。

残差与列空间正交，就是与每一列 $\boldsymbol{a}_j$ 正交，合写为 $\boldsymbol{A}^{\top}\boldsymbol{r} = \boldsymbol{0}$。代入 $\boldsymbol{r} = \boldsymbol{b} - \boldsymbol{A}\hat{\boldsymbol{x}}$，得到**正规方程**（normal equations）

$$\boldsymbol{A}^{\top}\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{A}^{\top}\boldsymbol{b}. \tag{9.5}$$

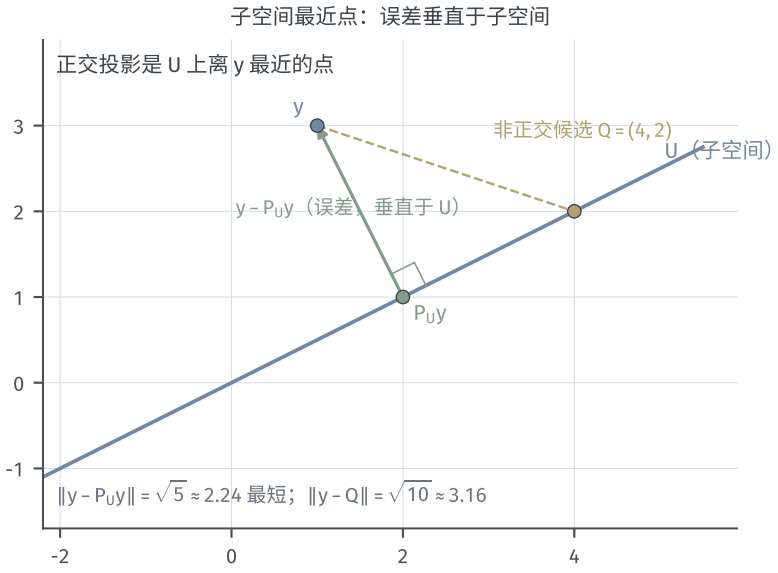


图 9.2 直线子空间 U（过原点、方向 $(2,1)$）上离 $\boldsymbol{y}=(1,3)^{\top}$ 最近的点是正交投影 $\boldsymbol{p}=(2,1)^{\top}$，误差 $\boldsymbol{y}-\boldsymbol{p}=(-1,2)^{\top}$ 与 U 垂直（直角小方块）；同一线上的另一候选 $\boldsymbol{q}=(4,2)^{\top}$ 到 $\boldsymbol{y}$ 的距离 $\sqrt{10}$ 明显大于最短距离 $\sqrt{5}$。这是解析式教学构造。

“正规”指法向，即残差沿列空间的法方向。由上一段，$\hat{\boldsymbol{x}}$ 是最小二乘解当且仅当它满足正规方程。这个条件完全由正交分解推出，不需要梯度、Hessian 或一般最优化的一阶条件。向量 $\boldsymbol{A}^{\top}\boldsymbol{r}$ 以下称为正规残差，它为零正是最小二乘的最优性条件。

拟合值随 $\boldsymbol{b}$ 线性变化，可以写成投影矩阵。设 $\boldsymbol{Q}_1$ 的列是 $\operatorname{range}(\boldsymbol{A})$ 的一组标准正交基，到列空间的正交投影为 $\boldsymbol{P}=\boldsymbol{Q}_1\boldsymbol{Q}_1^{\top}$（第 3.5.4节），于是拟合值与残差分别是 $\boldsymbol{P}\boldsymbol{b}$ 与 $(\boldsymbol{I}-\boldsymbol{P})\boldsymbol{b}$。$\boldsymbol{A}$ 满列秩时，由正规方程得 $\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}(\boldsymbol{A}^{\top}\boldsymbol{A})^{-1}\boldsymbol{A}^{\top}\boldsymbol{b}$ 对一切 $\boldsymbol{b}$ 成立，所以

$$\boldsymbol{P}=\boldsymbol{A}(\boldsymbol{A}^{\top}\boldsymbol{A})^{-1}\boldsymbol{A}^{\top}. \tag{9.6}$$

它对称且幂等：对称说明残差与拟合值正交，幂等说明拟合值再拟合一次不变。这些是几何描述，实际求解只需要系数 $\hat{\boldsymbol{x}}$，不必形成这个 $m\times m$ 矩阵。

正规方程是否总有解、有多少个解，仍由列空间与零空间回答。下面的定理把最优性条件、存在性和唯一性合在一起，后面各种最小二乘算法都以它为正确性依据。

定理 9.3 最小二乘解的刻画 对任意 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$ 与 $\boldsymbol{b}\in\mathbb{R}^{m}$，$\hat{\boldsymbol{x}}$ 是问题 (9.3)的解当且仅当它满足正规方程 (9.5)。最小二乘解总存在，全部解为 $\hat{\boldsymbol{x}}+\ker\boldsymbol{A}$，它们有相同的拟合值 $\boldsymbol{P}\boldsymbol{b}$ 与残差。解唯一当且仅当 $\boldsymbol{A}$ 满列秩，此时 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 正定，$\hat{\boldsymbol{x}}=(\boldsymbol{A}^{\top}\boldsymbol{A})^{-1}\boldsymbol{A}^{\top}\boldsymbol{b}$。

证明　由式 (9.4)，$\hat{\boldsymbol{x}}$ 最优当且仅当 $\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{P}\boldsymbol{b}$。$\boldsymbol{A}\hat{\boldsymbol{x}}$ 属于列空间，由正交分解的唯一性，这又等价于 $\boldsymbol{b} - \boldsymbol{A}\hat{\boldsymbol{x}} \perp \operatorname{range}(\boldsymbol{A})$，即正规方程。$\boldsymbol{P}\boldsymbol{b}$ 属于列空间，至少有一个系数向量实现它，所以解存在。若 $\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{x} = \boldsymbol{0}$，则 $\|\boldsymbol{A}\boldsymbol{x}\|_2^2 = \boldsymbol{x}^{\top}\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{x} = 0$，反向包含是直接的，故

$$\ker(\boldsymbol{A}^{\top}\boldsymbol{A}) = \ker \boldsymbol{A}, \tag{9.7}$$

正规方程的解集是一个特解加上 $\ker \boldsymbol{A}$，而核向量不改变 $\boldsymbol{A}\boldsymbol{x}$。解唯一当且仅当 $\ker \boldsymbol{A} = \{\boldsymbol{0}\}$，即满列秩；这时对 $\boldsymbol{x} \neq \boldsymbol{0}$ 有 $\boldsymbol{x}^{\top}\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{x} = \|\boldsymbol{A}\boldsymbol{x}\|_2^2 > 0$，$\boldsymbol{A}^{\top}\boldsymbol{A}$ 正定。 ■

定理区分了两层唯一性：拟合值总是唯一的，系数只在 $\boldsymbol{A}$ 满列秩时唯一。相容方程是残差为零的特例：$\boldsymbol{P}\boldsymbol{b} = \boldsymbol{b}$，最小二乘解集就是精确解集。

示例 9.4　三条不相容观测的最佳折中　现在回到示例 9.2中无解的观测 $\boldsymbol{b} = (1, 2, 2)^{\top}$，看最小二乘怎样在三条互相矛盾的等式之间取舍。由 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 与 $\boldsymbol{A}^{\top}\boldsymbol{b}$ 写出正规方程

$$\begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix} \hat{\boldsymbol{x}} = \begin{bmatrix} 5 \\ 6 \end{bmatrix},$$

解得 $\hat{\boldsymbol{x}} = (7/6, 1/2)^{\top}$，拟合值为 $(7/6, 5/3, 13/6)^{\top}$，残差 $\boldsymbol{r} = \boldsymbol{b} - \boldsymbol{A}\hat{\boldsymbol{x}} = (-1/6, 1/3, -1/6)^{\top}$。按定理，残差应与两列都正交：$\boldsymbol{A}^{\top}\boldsymbol{r}$ 的两个分量分别为 $-\frac{1}{6} + \frac{1}{3} - \frac{1}{6} = 0$ 与 $\frac{1}{3} - \frac{2}{6} = 0$，确实如此。残差平方和为 $1/6$，不为零。

三条观测不能同时满足，最小二乘给出它们的最佳折中：中间时刻的观测高于拟合直线，两端低于它。对相容观测 $(1, 2, 3)^{\top}$，同样的正规方程给出 $(1, 1)^{\top}$ 与零残差，可见精确求解就是最优残差为零时的同一目标。

满列秩只保证系数唯一，不保证系数稳定。设计矩阵的两列接近共线时，这一点最明显。

示例 9.5　近共线设计　下面用参数 ε 控制两列的夹角，观察系数怎样随它变化。取非零正交向量 $\boldsymbol{c}, \boldsymbol{q}$，设计矩阵的两列为 $\boldsymbol{c}$ 与 $\boldsymbol{c} + \varepsilon\boldsymbol{q}$，观测为 $\boldsymbol{y} = \boldsymbol{c} + \delta\boldsymbol{q}$。由 $w_1\boldsymbol{c} + w_2(\boldsymbol{c} + \varepsilon\boldsymbol{q}) = (w_1 + w_2)\boldsymbol{c} + \varepsilon w_2\boldsymbol{q}$，拟合值只依赖 $w_1 + w_2$ 与 εw_2。$\varepsilon \neq 0$ 时，系数

$$\hat{\boldsymbol{w}} = \left(1 - \frac{\delta}{\varepsilon},\ \frac{\delta}{\varepsilon}\right)^{\top}$$

精确拟合 $\boldsymbol{y}$，残差为零。$\varepsilon = 0$ 时两列重合，只能拟合 $\boldsymbol{c}$ 分量，残差跳到 $\delta\boldsymbol{q}$，凡满足 $w_1 + w_2 = 1$ 的系数都是解。

对照三个对象：$\varepsilon \to 0$ 时拟合值从 $\boldsymbol{y}$ 突变为 $\boldsymbol{c}$，系数则趋于无穷，并对 ε、δ 极为敏感。这是近共线几何本身的性质，不是舍入造成的，第 14.1.3节用奇异值量化这种敏感性。

9.3 最小范数解

最小二乘解集 $\hat{\boldsymbol{x}} + \ker \boldsymbol{A}$ 在秩亏时含无穷多个点，方程本身不指定其中哪一个。为报告一个确定的答案，需要额外的选解条件，最常用的是取欧氏范数最小者，称为**最小范数解**（minimum-norm solution）。所用的工具是输入空间的正交直和 $\mathbb{R}^d = \operatorname{range}(\boldsymbol{A}^{\top}) \oplus \ker \boldsymbol{A}$（定理 3.60）：核分量不影响拟合，却增加长度，所以应当去掉。

定理 9.6　最小范数代表　对任意 $\boldsymbol{A}$ 与 $\boldsymbol{b}$，最小二乘解中存在唯一的欧氏范数最小者 $\boldsymbol{x}_\star$，它是解集中唯一落在 $\operatorname{range}(\boldsymbol{A}^{\top})$ 中的点。方程相容时，$\boldsymbol{x}_\star$ 是精确解中范数最小者；方程有唯一解时，$\boldsymbol{x}_\star$ 就是这个解。

证明　把任一最小二乘解写成 $\boldsymbol{x} = \boldsymbol{x}_R + \boldsymbol{x}_N$，$\boldsymbol{x}_R \in \operatorname{range}(\boldsymbol{A}^{\top})$，$\boldsymbol{x}_N \in \ker \boldsymbol{A}$。$\boldsymbol{A}\boldsymbol{x}_R = \boldsymbol{A}\boldsymbol{x}$，去掉核分量不改变拟合值，$\boldsymbol{x}_R$ 仍是最小二乘解。两个解之差属于 $\ker \boldsymbol{A}$，它们的行空间分量之差既在 $\operatorname{range}(\boldsymbol{A}^{\top})$ 中又在 $\ker \boldsymbol{A}$ 中，只能为零，所以全部解共享同一个 $\boldsymbol{x}_\star = \boldsymbol{x}_R$。勾股关系给出 $\|\boldsymbol{x}\|_2^2 = \|\boldsymbol{x}_\star\|_2^2 + \|\boldsymbol{x}_N\|_2^2$，等号当且仅当 $\boldsymbol{x}_N = \boldsymbol{0}$。相容与唯一可解的情形是特例。 ■

至此出现了三层不同的确定性。拟合值 $\boldsymbol{P}\boldsymbol{b}$ 由 $\boldsymbol{b}$ 和列空间唯一决定；系数只在满列秩时由拟合值唯一决定；秩亏时，系数的唯一性来自额外的选解条件。选取代表的依据是事先给定的欧氏范数，并没有把多解方程改成唯一可解；换一个范数，选出的点一般也会改变。

$\boldsymbol{A}$ 满行秩时，“落在行空间中”这一刻画可以直接变成公式：所求的解形如 $\boldsymbol{x} = \boldsymbol{A}^{\top}\boldsymbol{w}$，代入方程得 $\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{w} = \boldsymbol{b}$。

定理 9.7　满行秩时的最小范数解　设 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$ 满行秩。则 $\boldsymbol{A}\boldsymbol{A}^{\top}$ 可逆，方程 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 对每个 $\boldsymbol{b}$ 相容，其最小范数解为

$$\boldsymbol{x}_\star = \boldsymbol{A}^{\top}(\boldsymbol{A}\boldsymbol{A}^{\top})^{-1}\boldsymbol{b}. \tag{9.8}$$

证明　与式 (9.7)同理，$\ker(\boldsymbol{A}\boldsymbol{A}^{\top}) = \ker \boldsymbol{A}^{\top}$，满行秩时它为 $\{\boldsymbol{0}\}$，所以 $\boldsymbol{A}\boldsymbol{A}^{\top}$ 可逆。右端满足 $\boldsymbol{A}\boldsymbol{x}_{\star} = \boldsymbol{b}$，并且落在 $\operatorname{range}(\boldsymbol{A}^{\top})$ 中，由定理 9.6，它就是最小范数解。 ■

式 (9.8)说明解是各行的组合，组合系数由 m 阶方程确定。计算时是形成 Gram 矩阵 $\boldsymbol{A}\boldsymbol{A}^{\top}$，还是对 $\boldsymbol{A}^{\top}$ 作 QR 分解，留到第 10.6节与第 10.7节比较。$\boldsymbol{A}$ 既不满行秩也不满列秩时，两个满秩公式都不能用，下一节用奇异值分解写出一般秩下的统一公式。

9.4 伪逆与解的表示

前三节规定了各种情形的处理方式：唯一可解时取这个解，无解时取最近的拟合值，多解时取范数最小的系数。一般的 $\boldsymbol{A}$ 可能既不满列秩也不满行秩，两种选择都要作。本节沿第 5章的奇异方向给出统一构造：对能够恢复的方向取逆，其他方向置为零；再用 Penrose 条件和两个正交投影说明这一构造不依赖分解的选取。

9.4.1 伪逆的构造

设 $\boldsymbol{A}$ 的秩为 r，奇异值分解为 $\boldsymbol{A} = \sum_{i=1}^{r} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^{\top}$（式 (5.1)），$\sigma_1 \geq \cdots \geq \sigma_r > 0$，并把 $\boldsymbol{u}_i$、$\boldsymbol{v}_i$ 分别扩充为 $\mathbb{R}^m$ 与 $\mathbb{R}^d$ 的标准正交基。$\boldsymbol{A}$ 把 $\boldsymbol{v}_i$ 伸缩为 $\sigma_i \boldsymbol{u}_i$，反过来自然应把 $\boldsymbol{u}_i$ 送回 $\boldsymbol{v}_i/\sigma_i$。

把 $\boldsymbol{b}$ 按 $\boldsymbol{u}_i$ 展开，三类分量的去向各不相同。分量 $\boldsymbol{u}_i^{\top}\boldsymbol{b}$（$i \leq r$）是可以拟合的部分，配给输入方向 $\boldsymbol{v}_i/\sigma_i$；$i > r$ 的分量落在 $\operatorname{range}(\boldsymbol{A})^{\perp}$ 中，没有原像，留在残差里；零空间方向 $\boldsymbol{v}_{r+1}, \ldots, \boldsymbol{v}_d$ 不分配任何分量。

定义 9.8　Moore–Penrose 伪逆　$\boldsymbol{A}$ 的Moore–Penrose 伪逆（Moore–Penrose pseudoinverse）为

$$\boldsymbol{A}^{\dagger} = \sum_{i=1}^{r} \frac{1}{\sigma_i} \boldsymbol{v}_i \boldsymbol{u}_i^{\top}, \tag{9.9}$$

$\boldsymbol{A} = \boldsymbol{0}$ 时规定 $\boldsymbol{A}^{\dagger} = \boldsymbol{0}$。

下面的定理说明，这一构造恰好完成了最小二乘与最小范数两次选择。

定理 9.9　伪逆给出最小范数最小二乘解　全部最小二乘解为 $\boldsymbol{A}^{\dagger}\boldsymbol{b} + \ker \boldsymbol{A}$，其中 $\boldsymbol{x}_{\star} = \boldsymbol{A}^{\dagger}\boldsymbol{b}$ 是唯一的最小范数解。

证明 记 $b_i = \boldsymbol{u}_i^{\top}\boldsymbol{b}$、$c_i = \boldsymbol{v}_i^{\top}\boldsymbol{x}$。由 $\boldsymbol{u}_i$ 标准正交，

$$\|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|_2^2 = \sum_{i=1}^{r}(\sigma_i c_i - b_i)^2 + \sum_{i=r+1}^{m} b_i^2 .$$

第二项与 $\boldsymbol{x}$ 无关，第一项当且仅当 $c_i = b_i/\sigma_i\,(i \le r)$ 时为零，$c_{r+1},\dots,c_d$ 任取。前者正是 $\boldsymbol{A}^{\dagger}\boldsymbol{b}$ 的坐标，后者组成任意核向量。$\boldsymbol{A}^{\dagger}\boldsymbol{b}$ 只含 $\boldsymbol{v}_1,\dots,\boldsymbol{v}_r$ 方向，与核向量正交，由定理 9.6，它是最小范数解。 ■

定理对秩和 $\boldsymbol{b}$ 的位置都没有要求，前面的公式都是它的特例。$\boldsymbol{A}$ 满列秩时核为零，最小二乘解唯一，所以 $\boldsymbol{A}^{\dagger} = (\boldsymbol{A}^{\top}\boldsymbol{A})^{-1}\boldsymbol{A}^{\top}$；满行秩时每个右端都相容，由式 (9.8)，$\boldsymbol{A}^{\dagger} = \boldsymbol{A}^{\top}(\boldsymbol{A}\boldsymbol{A}^{\top})^{-1}$；$\boldsymbol{A}$ 可逆时两式都化为 $\boldsymbol{A}^{-1}$。一般秩时两次选择都真正起作用，只有和式 (9.9)可用。

显式写出逆或伪逆只是数学表达。实际计算让分解因子依次作用于右端，不形成 $\boldsymbol{A}^{\dagger}$，步骤见第 10.8节。

示例 9.10　复制常数列后的最小范数拟合　把示例 9.2的两种缺陷合在一起：既复制常数列，又使用不相容的观测，

$$\widetilde{\boldsymbol{A}} = \begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 1 \\ 1 & 2 & 1 \end{bmatrix}, \qquad \boldsymbol{b} = (1,2,2)^{\top}.$$

这时最小二乘解不唯一，需要最小范数来选出代表。拟合值 $\widetilde{\boldsymbol{A}}\boldsymbol{x} = (x_1 + x_3)\boldsymbol{a}_1 + x_2\boldsymbol{a}_2$ 只依赖两个常数系数之和，所以最佳拟合值与示例 9.4相同，全部最小二乘解满足 $x_1 + x_3 = 7/6$、$x_2 = 1/2$，即 $(7/6 - t,\, 1/2,\, t)^{\top}$，$t \in \mathbb{R}$。在这条直线上找离原点最近的点：范数平方 $(7/6 - t)^2 + t^2 + 1/4$ 在 $t = 7/12$ 时最小，最小范数代表为 $\boldsymbol{x}_{\star} = (7/12, 1/2, 7/12)^{\top}$。

这个代表与核方向 $(1,0,-1)^{\top}$ 的内积为 $7/12 - 7/12 = 0$，正如定理所说落在行空间中。两次选择的分工由此可见：最小二乘选定拟合值，最小范数再在实现它的系数中，把常数项平均分给两个相同的列。

9.4.2 Penrose 条件与正交投影

奇异向量不唯一，例如重奇异值对应的奇异向量可以在子空间内任意旋转。要说明 $\boldsymbol{A}^{\dagger}$ 与所选分解无关，需要不提奇异向量、又能唯一确定它的条件。

定理 9.11　Penrose 条件　$\boldsymbol{G}=\boldsymbol{A}^{\dagger}$ 满足

$$\boldsymbol{A}\boldsymbol{G}\boldsymbol{A}=\boldsymbol{A},\qquad \boldsymbol{G}\boldsymbol{A}\boldsymbol{G}=\boldsymbol{G},$$
$$(\boldsymbol{A}\boldsymbol{G})^{\top}=\boldsymbol{A}\boldsymbol{G},\qquad (\boldsymbol{G}\boldsymbol{A})^{\top}=\boldsymbol{G}\boldsymbol{A},$$

并且满足这四个条件的 $\boldsymbol{G}\in\mathbb{R}^{d\times m}$ 只有一个。

证明　由和式与奇异向量的标准正交性，$\boldsymbol{A}\boldsymbol{A}^{\dagger}=\sum_{i\le r}\boldsymbol{u}_i\boldsymbol{u}_i^{\top}$，$\boldsymbol{A}^{\dagger}\boldsymbol{A}=\sum_{i\le r}\boldsymbol{v}_i\boldsymbol{v}_i^{\top}$，二者对称，再右乘 $\boldsymbol{A}$ 或 $\boldsymbol{A}^{\dagger}$ 即得前两条。反过来设 $\boldsymbol{G}$ 满足四个条件。由第一条，$\boldsymbol{A}\boldsymbol{G}$ 幂等且 $\operatorname{range}(\boldsymbol{A}\boldsymbol{G})=\operatorname{range}(\boldsymbol{A})$，再由第三条，它是到 $\operatorname{range}(\boldsymbol{A})$ 的正交投影；同理 $\boldsymbol{G}\boldsymbol{A}$ 是对称幂等矩阵，零空间为 $\ker\boldsymbol{A}$，因而是到 $(\ker\boldsymbol{A})^{\perp}$ 的正交投影。正交投影由子空间唯一决定，所以 $\boldsymbol{A}\boldsymbol{G}=\boldsymbol{A}\boldsymbol{A}^{\dagger}$、$\boldsymbol{G}\boldsymbol{A}=\boldsymbol{A}^{\dagger}\boldsymbol{A}$，于是

$$\boldsymbol{G}=\boldsymbol{G}\boldsymbol{A}\boldsymbol{G}=\boldsymbol{A}^{\dagger}\boldsymbol{A}\boldsymbol{G}=\boldsymbol{A}^{\dagger}\boldsymbol{A}\boldsymbol{A}^{\dagger}=\boldsymbol{A}^{\dagger}.$$

■

四个条件不必死记。前两条是在可恢复方向上的一致性：第一条说明，对能实现的输出 $\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}$，$\boldsymbol{G}\boldsymbol{y}$ 确实实现它；第二条说明，$\boldsymbol{G}$ 的输出不含被 $\boldsymbol{A}$ 消去的多余成分。只有前两条时，$\boldsymbol{A}\boldsymbol{G}$ 与 $\boldsymbol{G}\boldsymbol{A}$ 是幂等矩阵，但可以是斜投影；后两条的对称性要求它们是正交投影，分别对应“取最近的拟合值”和“取范数最小的系数”。正因为四个条件不涉及奇异向量，$\boldsymbol{A}^{\dagger}$ 不依赖奇异值分解的选取。

由证明，$\boldsymbol{A}\boldsymbol{A}^{\dagger}$ 是到列空间的正交投影，$\boldsymbol{A}^{\dagger}\boldsymbol{A}$ 是到行空间 $\operatorname{range}(\boldsymbol{A}^{\top})$ 的正交投影。两次选择因此写成两个可以检查的等式：$\boldsymbol{A}\boldsymbol{x}_\star=\boldsymbol{A}\boldsymbol{A}^{\dagger}\boldsymbol{b}=\boldsymbol{P}\boldsymbol{b}$ 说明拟合值是 $\boldsymbol{b}$ 在列空间上的投影，$\boldsymbol{A}^{\dagger}\boldsymbol{A}\boldsymbol{x}_\star=\boldsymbol{x}_\star$ 说明 $\boldsymbol{x}_\star$ 不含零空间分量。

在示例 9.10中，$\widetilde{\boldsymbol{A}}\boldsymbol{x}_\star=(7/6,5/3,13/6)^{\top}$ 与示例 9.4的拟合值相同；$\boldsymbol{x}_\star=\frac{7}{12}(1,0,1)^{\top}+\frac{1}{2}(0,1,0)^{\top}$ 是 $\widetilde{\boldsymbol{A}}$ 的两行之组合，已在行空间中，投影不改变它。

统一公式也暴露了一个代价：小正奇异值取倒数后增益 $1/\sigma_i$ 很大，数据误差会被放大。第 14.1节再量化这一敏感性；这里先完成各类解的统一表达，为随后选择计算方法提供目标。

9.5 加权最小二乘

前面都用欧氏长度度量残差，各坐标同等对待。不同观测的可靠程度不同，或观测误差彼此相关时，应按给定的权重度量残差。给定对称正定 $\boldsymbol{M} \in \mathbb{R}^{m\times m}$，**加权最小二乘**（weighted least squares）问题为

$$\min_{\boldsymbol{x}} (\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b})^{\top}\boldsymbol{M}(\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}). \tag{9.10}$$

权矩阵的两类元素分别改变目标的不同方面。$\boldsymbol{M}=\operatorname{diag}(m_1,\dots,m_m)$ 时目标为 $\sum_i m_i r_i^2$，m_i 越大，第 i 个观测的误差越昂贵，拟合值就越被拉向这个观测；这适合观测精度不同的情形。非对角元引入交叉项 $2m_{ij}r_i r_j$，使惩罚依赖残差的方向组合。例如 $\boldsymbol{M}=\begin{bmatrix}2 & -1\\ -1 & 2\end{bmatrix}$ 时，残差 $(1,1)^{\top}$ 的代价为 2，残差 $(1,-1)^{\top}$ 的代价为 6：两个观测同向偏离被看得较轻，反向偏离被看得较重，这适合两个观测的误差倾向于一起偏移的情形。怎样由误差的统计性质选出 $\boldsymbol{M}$，不在本章讨论。

由 Gram 因子（定理 3.52）或正定平方根（第 6.2节），可写 $\boldsymbol{M}=\boldsymbol{R}^{\top}\boldsymbol{R}$，$\boldsymbol{R}$ 可逆，于是目标等于 $\|\boldsymbol{R}\boldsymbol{A}\boldsymbol{x}-\boldsymbol{R}\boldsymbol{b}\|_2^2$。这一步称为**白化**（whitening）：先把各坐标的误差变换到同一欧氏尺度，加权问题就成为 $\boldsymbol{R}\boldsymbol{A}$、$\boldsymbol{R}\boldsymbol{b}$ 上的普通最小二乘，定理 9.3的结论都可以搬过来。

定理 9.12　加权最小二乘解的刻画　设 $\boldsymbol{M}\in\mathbb{R}^{m\times m}$ 对称正定。则 $\hat{\boldsymbol{x}}$ 是问题 (9.10)的解当且仅当它满足加权正规方程

$$\boldsymbol{A}^{\top}\boldsymbol{M}(\boldsymbol{b}-\boldsymbol{A}\hat{\boldsymbol{x}})=\boldsymbol{0}. \tag{9.11}$$

这组方程总有解，全部解为 $\hat{\boldsymbol{x}}+\ker\boldsymbol{A}$；解唯一当且仅当 $\boldsymbol{A}$ 满列秩。

证明　对 $\boldsymbol{R}\boldsymbol{A}$ 与 $\boldsymbol{R}\boldsymbol{b}$ 应用定理 9.3：$\hat{\boldsymbol{x}}$ 最优当且仅当 $(\boldsymbol{R}\boldsymbol{A})^{\top}(\boldsymbol{R}\boldsymbol{b}-\boldsymbol{R}\boldsymbol{A}\hat{\boldsymbol{x}})=\boldsymbol{0}$，由 $\boldsymbol{R}^{\top}\boldsymbol{R}=\boldsymbol{M}$，这正是式 (9.11)。解存在，解集是一个特解加上 $\ker(\boldsymbol{R}\boldsymbol{A})$；$\boldsymbol{R}$ 可逆，故 $\ker(\boldsymbol{R}\boldsymbol{A})=\ker\boldsymbol{A}$。 ■

加权正规方程说明残差在 $\boldsymbol{M}$ 内积下与列空间正交。权矩阵改变的是误差的度量，不改变系数和拟合值的含义。若 $\boldsymbol{M}$ 只是半正定，$\ker\boldsymbol{M}$ 中的残差分量不受惩罚，$\boldsymbol{R}$ 奇异，唯一性要求 $\ker(\boldsymbol{M}\boldsymbol{A})=\{\boldsymbol{0}\}$，拟合值本身也可能不唯一，正定版本的结论不能全部沿用。

$\boldsymbol{A}$ 满列秩时，加权拟合值为 $\boldsymbol{P}_{\boldsymbol{M}}\boldsymbol{b}$，其中 $\boldsymbol{P}_{\boldsymbol{M}}=\boldsymbol{A}(\boldsymbol{A}^{\top}\boldsymbol{M}\boldsymbol{A})^{-1}\boldsymbol{A}^{\top}\boldsymbol{M}$。它幂等，一般不对称，在欧氏内积下是斜投影。但对任意 $\boldsymbol{u},\boldsymbol{v}$，$\boldsymbol{u}^{\top}\boldsymbol{M}\boldsymbol{P}_{\boldsymbol{M}}\boldsymbol{v}=\boldsymbol{u}^{\top}\boldsymbol{M}\boldsymbol{A}(\boldsymbol{A}^{\top}\boldsymbol{M}\boldsymbol{A})^{-1}\boldsymbol{A}^{\top}\boldsymbol{M}\boldsymbol{v}$ 关于 $\boldsymbol{u},\boldsymbol{v}$ 对称，所以 $\boldsymbol{P}_{\boldsymbol{M}}$ 在 $\boldsymbol{M}$ 内积下自伴，是该

内积下的正交投影。同一组 $\boldsymbol{A},\boldsymbol{b}$ 换用不同权矩阵，最近点随之移动，如下例与图 9.3所示。

白化只变换观测端，未知量和它的欧氏范数都不变，所以加权问题与白化后普通问题的解集相同。秩亏时，最小范数代表仍按原系数的欧氏范数选取，即白化后问题的 $(\boldsymbol{RA})^{\dagger}\boldsymbol{Rb}$；构造权因子并调用求解方法的步骤见第 10.8节。

示例 9.13　同一直线上的两种最近点　用最简单的单列情形比较两种内积下的最近点。取 $\boldsymbol{A}=(1,1)^{\mathsf{T}}$、$\boldsymbol{b}=(2,1)^{\mathsf{T}}$，拟合值都形如 $a(1,1)^{\mathsf{T}}$。欧氏正规方程为 $2a=3$，最近点是 $(1.5,1.5)^{\mathsf{T}}$，坐标取两个观测的平均。改用 $\boldsymbol{M}=\operatorname{diag}(1,4)$ 后，加权正规方程 $\boldsymbol{A}^{\mathsf{T}}\boldsymbol{M}\boldsymbol{A}\,a=\boldsymbol{A}^{\mathsf{T}}\boldsymbol{M}\boldsymbol{b}$ 成为 $5a=6$，最近点移到 $(1.2,1.2)^{\mathsf{T}}$：第二个坐标的误差代价更大，最近点向 $b_2=1$ 靠近。

加权解的残差 $(0.8,-0.2)^{\mathsf{T}}$ 与 $(1,1)^{\mathsf{T}}$ 的欧氏内积为 0.6，加权内积却是 $0.8-4\times0.2=0$。残差只在所选的内积下与列空间正交；若用欧氏内积去检查加权解，会误以为它不满足最优条件。

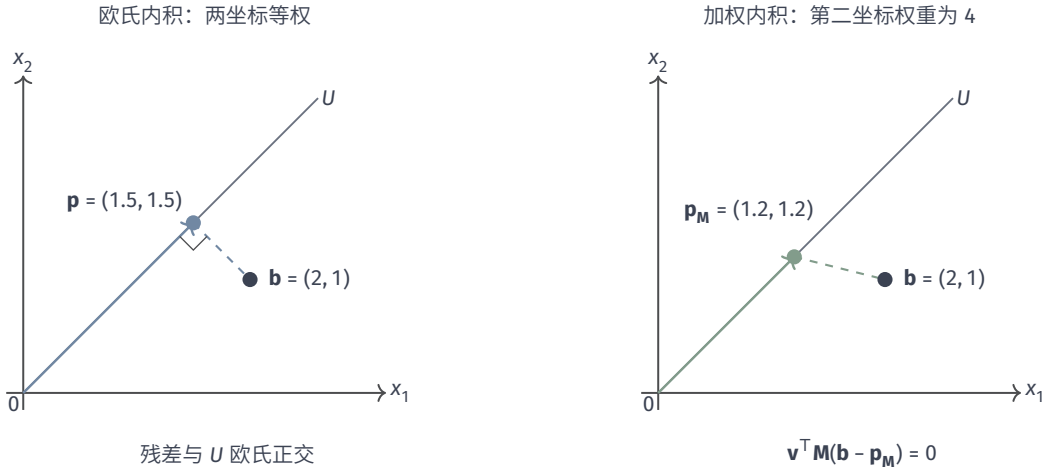


图 9.3　同一目标在同一直线上的欧氏投影与加权投影。实箭头是投影向量，虚线是残差；右图画在普通坐标中，残差不必形成欧氏直角。正交性必须用所选内积判断。

9.6　齐次最小二乘

另一类拟合问题的模型写成 $\boldsymbol{A}\boldsymbol{h}\approx\boldsymbol{0}$，只确定参数的比例。例如用直线 $h_1u+h_2v+h_3=0$ 拟合平面上的点 (u_j,v_j)，每个点给出一行 $[\,u_j\ v_j\ 1\,]$，$\boldsymbol{h}$ 乘以非零常数描述同一条直线。直接最小化 $\|\boldsymbol{A}\boldsymbol{h}\|_2^2$ 总得到无意义的 $\boldsymbol{h}=\boldsymbol{0}$，所以必须先固定尺度。

固定一个分量，例如 $h_3 = 1$，会把问题化为普通最小二乘；但真实直线过原点时 $h_3 = 0$，这一归一化恰好排除了它。固定欧氏长度则对各分量一视同仁，得到**齐次最小二乘**（homogeneous least squares）问题

$$\min_{\|\boldsymbol{h}\|_2=1} \|\boldsymbol{A}\boldsymbol{h}\|_2^2 = \min_{\|\boldsymbol{h}\|_2=1} \boldsymbol{h}^{\top}\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{h}. \tag{9.12}$$

它与求齐次方程 $\boldsymbol{A}\boldsymbol{h} = \boldsymbol{0}$ 的全部解不同：后者的解集是子空间 $\ker \boldsymbol{A}$，满列秩时只含零向量；前者总给出一个最接近满足的单位方向。右端是对称半正定矩阵 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 的二次型在单位向量上的最小值，由第 5章构造奇异值分解时所用的特征基即可求出。

定理 9.14　齐次最小二乘的最优解　设 $\lambda_{\min}$ 为 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 的最小特征值。则问题 (9.12)的最小值存在且等于 $\lambda_{\min}$，最优解恰为特征空间 $\ker(\boldsymbol{A}^{\top}\boldsymbol{A} - \lambda_{\min}\boldsymbol{I})$ 中的单位向量。$\lambda_{\min}$ 单重时最优解只差一个符号；$\ker \boldsymbol{A} \neq \{\boldsymbol{0}\}$ 时 $\lambda_{\min} = 0$，任一单位零空间向量都是最优解。

证明　取 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 的标准正交特征基 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_d$，特征值 $\lambda_1 \geq \cdots \geq \lambda_d = \lambda_{\min} \geq 0$，这正是构造奇异值分解时所用的右奇异向量。单位向量写成 $\boldsymbol{h} = \sum_i c_i \boldsymbol{v}_i$，$\sum_i c_i^2 = 1$，则

$$\boldsymbol{h}^{\top}\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{h} = \sum_{i=1}^{d} \lambda_i c_i^2 \geq \lambda_{\min} \sum_{i=1}^{d} c_i^2 = \lambda_{\min},$$

取 $\boldsymbol{h} = \boldsymbol{v}_d$ 时等号成立，所以最小值存在且等于 $\lambda_{\min}$。等号成立当且仅当 $\lambda_i > \lambda_{\min}$ 的系数 c_i 都为零，即 $\boldsymbol{h}$ 属于 $\lambda_{\min}$ 的特征空间。特征空间一维时其中的单位向量只有一对 $\pm\boldsymbol{h}_\star$。由式 (9.7)，$\ker \boldsymbol{A} = \ker(\boldsymbol{A}^{\top}\boldsymbol{A})$；它非零时 0 是特征值，而半正定矩阵的特征值非负，故 $\lambda_{\min} = 0$。 ■

用 $\boldsymbol{A} = [\,1 \;\; -2\,]$ 核验：$\boldsymbol{A}^{\top}\boldsymbol{A}$ 的特征值为 0 与 5，最小特征值的单位特征向量为 $\pm(2,1)^{\top}/\sqrt{5}$，它满足 $h_1 - 2h_2 = 0$，残差为零，两个符号给出同一比例 $h_1 : h_2 = 2 : 1$。

换成奇异值的语言，右奇异向量是 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 的单位特征向量，特征值为奇异值的平方（$d > r$ 时补上零），所以最优解就是最小奇异值对应的右奇异子空间中的单位向量，最小值为最小奇异值的平方。同类的长度约束极值在第 15.2.2节推广为 Rayleigh 商的一般结论。

最小特征值接近重根时，任意小的数据扰动都可能从近似最优的子空间中选出不同的方向，最优方向的敏感度由第 7.2.3节的子空间界控制。这里只说明解的性质，用 SVD 选取具体单位向量的步骤见第 10.8节。

9.7　解的检验条件

算出候选解以后，要用与目标对应的条件核对它。不同目标的条件不同，用错条件会把正确的解判为失败，或把不满足目标的解当作成功。下面依次列出各目标的条件，对象都是候选解 $\boldsymbol{x}$ 及其原残差 $\boldsymbol{r} = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}$。

精确方程检查原残差：$\boldsymbol{r} = \boldsymbol{0}$。这只对相容方程适用；方程是否相容由式 (9.1)判断，而不是由残差能否降到零来猜测。

普通最小二乘检查正规残差：$\boldsymbol{A}^{\top}\boldsymbol{r} = \boldsymbol{0}$，同时报告残差范数 $\|\boldsymbol{r}\|_2$，它是 $\boldsymbol{b}$ 到列空间的距离。无解方程的最优残差本来就不为零：示例 9.4的残差范数为 $1/\sqrt{6}$，它满足 $\boldsymbol{A}^{\top}\boldsymbol{r} = \boldsymbol{0}$，并不说明求解失败。

要求最小范数解时，再检查行空间条件：$\boldsymbol{x} \perp \ker \boldsymbol{A}$，等价地，$\boldsymbol{A}^{\dagger}\boldsymbol{A}\boldsymbol{x} = \boldsymbol{x}$，或 $\boldsymbol{x} = \boldsymbol{A}^{\top}\boldsymbol{w}$ 对某个 $\boldsymbol{w}$ 成立。秩亏时系数不唯一本身也不是失败：示例 9.10中，$(7/6 - t, 1/2, t)^{\top}$ 对每个 t 都满足正规残差为零，若只要求最小二乘，它们都是合格答案；只有 $t = 7/12$ 还满足行空间条件。

加权问题核对 $\boldsymbol{A}^{\top}\boldsymbol{M}\boldsymbol{r} = \boldsymbol{0}$，报告 $\sqrt{\boldsymbol{r}^{\top}\boldsymbol{M}\boldsymbol{r}}$ 并说明所用的权矩阵；示例 9.13中欧氏的 $\boldsymbol{A}^{\top}\boldsymbol{r} = 0.6 \neq 0$，这不是错误。齐次拟合不能照搬 $\boldsymbol{A}^{\top}\boldsymbol{r} = \boldsymbol{0}$，否则只会把解推向零向量；应检查 $\|\boldsymbol{h}\|_2 = 1$，并确认 $\boldsymbol{h}$ 是 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 最小特征值的特征方向。

这些条件规定了后续算法应该达到什么。浮点计算中“为零”要换成相对容限，容限怎样确定、残差小能否保证误差小，在第 14.1.2节讨论；直接法的分解质量与迭代法的停止条件分别见第 10.9节、第 11.7节和第 12.12节。

9.8　本章小结

本章回答了反求输入时要求什么样的解。方程 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 相容当且仅当 $\boldsymbol{b} \in \operatorname{range}(\boldsymbol{A})$，即 $\operatorname{rank}[\boldsymbol{A}\ \boldsymbol{b}] = \operatorname{rank}\boldsymbol{A}$；相容时全部解是一个特解加上 $\ker \boldsymbol{A}$，自由度为 $d - \operatorname{rank}\boldsymbol{A}$。方程个数与未知量个数不能单独决定这些情况，满列秩只保证至多一解，满行秩只保证有解。

无解时改求最小二乘解。由正交分解，最优拟合值是 $\boldsymbol{b}$ 在列空间上的正交投影，总存在且唯一；系数是最小二乘解当且仅当正规残差 $\boldsymbol{A}^{\top}(\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x})$ 为零，全部解为一个解加上 $\ker \boldsymbol{A}$，只在满列秩时唯一。近共线的例子说明，系数唯一不等于系数稳定。

解不唯一时，用欧氏范数作额外的选解条件：最小范数解唯一，并且是解集中唯一落在行空间 $\operatorname{range}(\boldsymbol{A}^{\top})$ 中的点。伪逆 $\boldsymbol{A}^{\dagger}$ 沿正奇异值方向取逆、其余方向置零，$\boldsymbol{A}^{\dagger}\boldsymbol{b}$ 同时完成最小二乘与最小范数两次选择；四个 Penrose 条件不提奇异向量就唯一确定它，$\boldsymbol{A}\boldsymbol{A}^{\dagger}$ 与 $\boldsymbol{A}^{\dagger}\boldsymbol{A}$ 分别是到列空间与行空间的正交投影。小奇异值取倒数会放大数据误差，这是统一公式的边界。

加权最小二乘改变残差的度量：对称正定权矩阵经白化化为普通问题，最优条件变为 $\boldsymbol{A}^{\top}\boldsymbol{M}\boldsymbol{r}=\boldsymbol{0}$，最小范数代表仍按原系数的欧氏范数选取。齐次最小二乘改变约束：在单位长度下最小化 $\|\boldsymbol{A}\boldsymbol{h}\|_2$，解是最小奇异值对应的右奇异方向，它不同于求 $\ker \boldsymbol{A}$ 中的全部解。

各目标都对应可以核对的条件：精确方程看原残差，最小二乘看正规残差，最小范数再看行空间条件，加权与齐次问题按各自的度量和约束检查。残差非零或系数不唯一都可能是正确结果。本章只确定目标；第 10章起讨论怎样计算这些解，第 14章讨论在误差下如何判断结果的可信程度。

第 10 章

直接求解方法

第 9章回答了“要求哪一个解”：方程相容且解唯一时求精确解，不相容时求最小二乘解，解不唯一时取范数最小的代表；该章还给出了检验这些目标的条件（第 9.7节）。但目标确定以后，解并不会自动出现。$\boldsymbol{x}_\star = \boldsymbol{A}^{-1}\boldsymbol{b}$ 与 $\hat{\boldsymbol{x}} = (\boldsymbol{A}^\top\boldsymbol{A})^{-1}\boldsymbol{A}^\top\boldsymbol{b}$ 只是解的表达式：先求逆再相乘要多做运算，显式形成 $\boldsymbol{A}^\top\boldsymbol{A}$ 还可能在有限精度下丢失信息。本章研究怎样不求逆，在有限步内把选定的解算出来，并让同一次分解服务于多个右端。

本章的共同做法是把原问题化为容易求解的问题。消元把一般方阵化为三角方程，三角方程可以逐个分量代入求解；正交变换保持欧氏长度，把最小二乘化为三角方程；奇异值分解则把问题拆成互不耦合的标量问题。这类在精确算术下经有限步给出答案的方法称为直接法，它们与第 11章起的迭代法相对。

各节按两条线索组织。第一条线索是矩阵结构，对应前五节：一般非奇异方阵用带部分选主元的 LU 分解，对称正定矩阵用 Cholesky 分解，对称不定矩阵用分块 LDL 分解。分块消元与低秩更新不是新的分解，而是说明怎样在块结构或低秩修改下复用前三种分解，只求解一个较小的方程。

第二条线索是求解目标，对应后三节：满列秩最小二乘可以化为正规方程再用 Cholesky 分解；QR 求解直接对 $\boldsymbol{A}$ 作正交三角化，并用修正 Gram–Schmidt 正交化、Householder 反射和 Givens 旋转三种方式计算因子；SVD 求解处理任意形状与秩的最小范数最小二乘，并推广到加权与齐次目标。最后一节按目标和结构归纳方法选择，并用原始数据核验结果。

本章依赖前文的三类结果。三角分解的存在性和 Schur 补的性质要用到行列式与正定矩阵（第 3.4.2.1节）；QR 求解用到第 3章的 Gram–Schmidt 正交化、QR 分解（第 3.5.3节）与正交投影（第 3.5.4节）；SVD 求解与条件数平方关系用到第 5章的奇异值分解。各算法的正确性在本章证明，稳定性只给出算法层面的结论，例如主元增长和条件数平方的影响；前向误差、后向误差与正则化的系统分析在第 14章展开。

记号沿用第 9章：已知 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$ 与 $\boldsymbol{b} \in \mathbb{R}^m$，未知量为 $\boldsymbol{x} \in \mathbb{R}^d$，方阵情形取 $m = d$；精确解或选定的最小范数解记作 $\boldsymbol{x}_\star$，满列秩最小二乘的

唯一解记作 $\hat{\boldsymbol{x}}$。每个算法都以 $\boldsymbol{A}$、$\boldsymbol{b}$ 为输入，以所求的 $\boldsymbol{x}$ 为输出；分解因子、置换、变换后的右端和残差只是中间量，主元或选块策略、权矩阵等需要预先选定的规则单独说明。若干右端排成 $\boldsymbol{B}=[\boldsymbol{b}_1\ \cdots\ \boldsymbol{b}_s]$ 时，方程写成 $\boldsymbol{AX}=\boldsymbol{B}$，各列分别求解并共用同一次分解。

每种算法都分三部分讲解：主要思想从需要满足的等式推导计算公式；算法实现按计算次序写出步骤，并给出可以逐步复算的算例；算法分析说明结果为什么正确、在什么条件下可以进行，以及计算代价与数值上的注意事项。

10.1 LU 分解

一般非奇异方阵没有对称性或正定性可以利用，最基本的求解方式是 Gauss 消元。本节把消元过程记录成两个三角因子，使求解化为两次三角代入；行交换用来避开零主元和过小的主元，因子一旦算出，换右端时可以直接复用。

10.1.1 主要思想

设 $\boldsymbol{A}\in\mathbb{R}^{d\times d}$ 非奇异，$\boldsymbol{b}\in\mathbb{R}^{d}$，要求 $\boldsymbol{Ax}=\boldsymbol{b}$ 的唯一精确解 $\boldsymbol{x}_{\star}$。做法是用行消元把 $\boldsymbol{A}$ 化为上三角矩阵 $\boldsymbol{U}$，同时把消元用到的乘子收集成单位下三角矩阵 $\boldsymbol{L}$；消元中的全部行交换累积为置换矩阵 $\boldsymbol{P}$，得到LU 分解

$$\boldsymbol{PA}=\boldsymbol{LU}. \tag{10.1}$$

下面依次推导一次消元的公式、这些公式怎样拼成式 (10.1)，以及分解之后怎样求解。

一次消元的乘子与尾部更新　记消元过程中的工作矩阵为 $\boldsymbol{W}$，开始时 $\boldsymbol{W}=\boldsymbol{A}$。设前 $k-1$ 列已经化为上三角形状，第 k 轮先把选好的主元行交换到第 k 行，使 $w_{k,k}\neq 0$。为了消去下方的 $w_{i,k}$（$i>k$），把第 i 行减去第 k 行的 $l_{i,k}$ 倍；新的第 k 个元素是 $w_{i,k}-l_{i,k}w_{k,k}$，令它为零，得到乘子

$$l_{i,k}=\frac{w_{i,k}}{w_{k,k}}.$$

同一次行操作也作用于第 i 行的其余元素，即

$$w_{i,j}\leftarrow w_{i,j}-l_{i,k}w_{k,j}\qquad (j=k+1,\dots,d).$$

前 $k-1$ 列在第 k 行和第 i 行上都已经是零，减去后仍为零，所以第 k 轮只改变右下角的 $(d-k)$ 阶尾块。被消去位置上的值已经确定为零，不必存储，乘子 $l_{i,k}$ 就保存在这个位置，构成 $\boldsymbol{L}$ 的第 k 列。

消元矩阵与分解　第 k 轮全部消元可以写成左乘一个矩阵。令 $\boldsymbol{\ell}_k = (0,\dots,0,l_{k+1,k},\dots,l_{d,k})^{\top}$，前 k 个分量为零，则第 k 轮相当于左乘 $\boldsymbol{M}_k = \boldsymbol{I}_d - \boldsymbol{\ell}_k \boldsymbol{e}_k^{\top}$：它把第 k 行的 $l_{i,k}$ 倍从第 i 行减去。因为 $\boldsymbol{e}_k^{\top}\boldsymbol{\ell}_k = 0$，有

$$(\boldsymbol{I}_d - \boldsymbol{\ell}_k \boldsymbol{e}_k^{\top})(\boldsymbol{I}_d + \boldsymbol{\ell}_k \boldsymbol{e}_k^{\top}) = \boldsymbol{I}_d - \boldsymbol{\ell}_k (\boldsymbol{e}_k^{\top}\boldsymbol{\ell}_k)\boldsymbol{e}_k^{\top} = \boldsymbol{I}_d,$$

即 $\boldsymbol{M}_k^{-1} = \boldsymbol{I}_d + \boldsymbol{\ell}_k \boldsymbol{e}_k^{\top}$。不交换行时，$\boldsymbol{M}_{d-1}\cdots\boldsymbol{M}_1\boldsymbol{A} = \boldsymbol{U}$，于是 $\boldsymbol{A} = \boldsymbol{M}_1^{-1}\cdots\boldsymbol{M}_{d-1}^{-1}\boldsymbol{U}$。对 $j<k$ 还有 $\boldsymbol{e}_j^{\top}\boldsymbol{\ell}_k = 0$，展开乘积时所有交叉项都消失，得到

$$\boldsymbol{M}_1^{-1}\cdots\boldsymbol{M}_{d-1}^{-1} = \boldsymbol{I}_d + \sum_{k=1}^{d-1} \boldsymbol{\ell}_k \boldsymbol{e}_k^{\top} = \boldsymbol{L},$$

所以乘子只需按位置填入 $\boldsymbol{L}$，不需要另做矩阵乘法。

有行交换时，第 k 轮先左乘交换第 k,r 两行（$r \ge k$）的置换矩阵 $\boldsymbol{P}_k$，再左乘 $\boldsymbol{M}_k$。$\boldsymbol{P}_k$ 只交换下标不小于 k 的两个位置，对 $j<k$ 有 $\boldsymbol{P}_k\boldsymbol{e}_j = \boldsymbol{e}_j$，因此

$$\boldsymbol{P}_k\boldsymbol{M}_j = \big(\boldsymbol{I}_d - (\boldsymbol{P}_k\boldsymbol{\ell}_j)\boldsymbol{e}_j^{\top}\big)\boldsymbol{P}_k.$$

这说明可以把 $\boldsymbol{P}_k$ 移到此前的消元矩阵右侧，代价是把已经保存的乘子向量 $\boldsymbol{\ell}_j$ 也交换第 k,r 两个分量。逐轮这样移动，全部置换合成 $\boldsymbol{P} = \boldsymbol{P}_{d-1}\cdots\boldsymbol{P}_1$，便得到式 (10.1)。这一推导也给出实现规则：后续交换两行时，$\boldsymbol{L}$ 中已经完成的前 $k-1$ 列必须同时交换这两行，否则保存的乘子不再对应同一个方程。

前代与回代　有了分解，把 $\boldsymbol{b}$ 按同一置换重排为 $\boldsymbol{c} = \boldsymbol{P}\boldsymbol{b}$，原方程等价于 $\boldsymbol{L}\boldsymbol{U}\boldsymbol{x} = \boldsymbol{c}$。令 $\boldsymbol{y} = \boldsymbol{U}\boldsymbol{x}$，它分成 $\boldsymbol{L}\boldsymbol{y} = \boldsymbol{c}$ 和 $\boldsymbol{U}\boldsymbol{x} = \boldsymbol{y}$ 两个三角方程。下三角方程的第一个方程只含 y_1；解出后，第二个方程只剩 y_2 未知。如此从 $i=1$ 到 d 逐个计算

$$y_i = \frac{c_i - \sum_{j<i} l_{i,j}\, y_j}{l_{i,i}}, \tag{10.2}$$

右侧只用到已经算出的 $y_1,\dots,y_{i-1}$。这种求解顺序称为**前代**；只要对角元都不为零，它逐个唯一地给出解。LU 中 $l_{i,i}=1$，除法可以省去。

上三角方程的最后一个方程只含 x_d，于是从 $i=d$ 到 1 逐个计算

$$x_i = \frac{y_i - \sum_{j>i} u_{i,j}\, x_j}{u_{i,i}}, \tag{10.3}$$

右侧只用到已经算出的 $x_{i+1},\dots,x_d$。这种求解顺序称为**回代**。图 10.1对比了两种顺序：前代自上而下，每个分量只依赖它上方已求出的分量；回代自下而上，依赖关系正好反过来。后面各节遇到三角方程时，直接调用前代和回代。分解只依赖 $\boldsymbol{A}$，换一个右端只需重新做这两次代入。

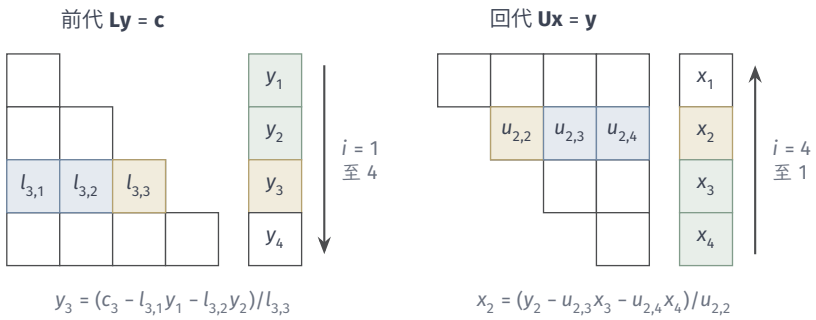


图 10.1 前代与回代的计算顺序。左为四阶下三角方程，计算 y_3 时只用到第三行的蓝色元素与绿色的已算分量 y_1, y_2；右为上三角方程，计算 x_2 时只用到 x_3, x_4。黄色是当前用作除数的对角元与正在计算的分量，箭头是计算方向。

10.1.2 算法实现

输入是 $\boldsymbol{A}$ 与 $\boldsymbol{b}$，需要预先选定的规则是主元策略。本小节固定使用**部分选主元**：在当前列尚未处理的元素中选绝对值最大者作主元，绝对值相同时取行号最小者，使给定数据下的计算过程可以复算。算法分为三步：先分解 $\boldsymbol{PA} = \boldsymbol{LU}$，再依次解两个三角方程。

LU 分解 初始化工作矩阵 $\boldsymbol{W} = \boldsymbol{A}$ 以及 $\boldsymbol{L} = \boldsymbol{I}_d$、$\boldsymbol{P} = \boldsymbol{I}_d$，对 $k = 1, \dots, d-1$ 依次处理第 k 列。先选主元：在第 k 列的第 k 至 d 行中找出使 $|w_{r,k}|$ 最大的行 r，交换 $\boldsymbol{W}$ 的第 k, r 两行，并对 $\boldsymbol{P}$ 作同样的行交换；$\boldsymbol{L}$ 前 $k-1$ 列已经保存的乘子也交换这两行，使它们始终跟随所在的方程。若选出的主元为零，说明输入不满足非奇异的前提，停止并报告本算法不适用；$\boldsymbol{A}$ 非奇异时这种情况不会出现，理由见定理 10.3。

然后对每个 $i > k$ 计算乘子 $l_{i,k} = w_{i,k}/w_{k,k}$，按 $w_{i,j} \leftarrow w_{i,j} - l_{i,k}w_{k,j}$（$j > k$）更新该行，再令 $w_{i,k} = 0$。每一步使用的都是工作矩阵的当前值，而不是最初的 $a_{i,j}$。处理完第 $d-1$ 列后 $\boldsymbol{W}$ 成为上三角矩阵，取 $\boldsymbol{U} = \boldsymbol{W}$。图 10.2用一个无需换行的三阶矩阵示意这一过程：乘子按被消元素的位置填入 $\boldsymbol{L}$。

前代与回代 分解完成后处理右端：计算 $\boldsymbol{c} = \boldsymbol{Pb}$，按式 (10.2)前代求解 $\boldsymbol{Ly} = \boldsymbol{c}$，再按式 (10.3)回代求解 $\boldsymbol{Ux} = \boldsymbol{y}$，输出 $\boldsymbol{x}$。精确算术下它就是 $\boldsymbol{x}_\star$；浮点实现中还应报告缩放残差 $\|\boldsymbol{b} - \boldsymbol{Ax}\|/(\|\boldsymbol{A}\|\|\boldsymbol{x}\| + \|\boldsymbol{b}\|)$，它的含义在第 14.1.2节解释。

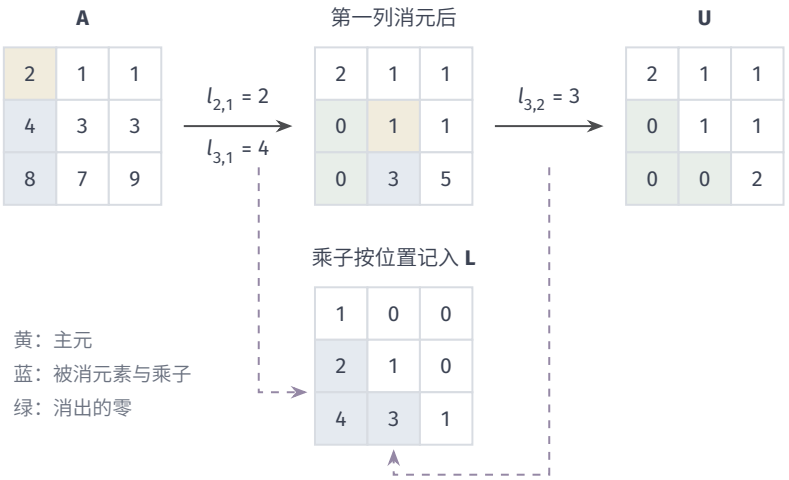


图 10.2　三阶矩阵的消元与 LU 因子。左起依次是 $\boldsymbol{A}$、消去第一列后的矩阵与 $\boldsymbol{U}$；黄色是当前主元，蓝色是待消去的元素，绿色是消出的零。箭头上的乘子等于被消元素除以主元，下方按原位置收集成单位下三角因子 $\boldsymbol{L}$，满足 $\boldsymbol{LU}=\boldsymbol{A}$。

示例 10.1　部分选主元 LU 的三步计算　下面按分解、前代、回代三步完整求解一个三阶方程。取

$$\boldsymbol{A}=\begin{bmatrix}1&3&4\\2&2&4\\1&2&5\end{bmatrix},\qquad \boldsymbol{b}=\begin{bmatrix}2\\4\\4\end{bmatrix}.$$

先分解。第一列中绝对值最大的是第二行的 2，于是交换第一、二行，$\boldsymbol{P}$ 也随之交换。乘子 $l_{2,1}=l_{3,1}=\tfrac{1}{2}$，消元后两行变为 $(0,2,2)$ 与 $(0,1,3)$。第二列剩余元素中 $|2|>|1|$，主元已在第二行，无需交换；乘子 $l_{3,2}=\tfrac{1}{2}$，第三行变为 $(0,0,2)$。于是

$$\boldsymbol{P}=\begin{bmatrix}0&1&0\\1&0&0\\0&0&1\end{bmatrix},\ \boldsymbol{L}=\begin{bmatrix}1&0&0\\\tfrac{1}{2}&1&0\\\tfrac{1}{2}&\tfrac{1}{2}&1\end{bmatrix},\ \boldsymbol{U}=\begin{bmatrix}2&2&4\\0&2&2\\0&0&2\end{bmatrix}.$$

分解完成后才处理右端。右端先按同样的行交换重排为 $\boldsymbol{c}=\boldsymbol{Pb}=(4,2,4)^{\mathsf{T}}$，前代依次得 $y_1=4, y_2=2-\tfrac{1}{2}\cdot 4=0, y_3=4-\tfrac{1}{2}\cdot 4-\tfrac{1}{2}\cdot 0=2$；再回代，$x_3=2/2=1$，$x_2=(0-2\cdot 1)/2=-1$，$x_1=(4-2\cdot(-1)-4\cdot 1)/2=1$。所以 $\boldsymbol{x}=(1,-1,1)^{\mathsf{T}}$，代回可验 $\boldsymbol{Ax}=(2,4,4)^{\mathsf{T}}=\boldsymbol{b}$。也可以单独验证 $\boldsymbol{LU}$ 等于交换前两行后的 $\boldsymbol{A}$，这项检查只涉及因子，与右端无关。

上例只在第一轮换行，已存乘子没有受到影响。下例在第二轮再次换行，用来检查“已存乘子随行交换”这条规则。

示例 10.2　第二轮换行时交换已存乘子　取

$$\boldsymbol{A}=\begin{bmatrix}0&2&1\\1&1&0\\2&0&1\end{bmatrix},\qquad \boldsymbol{b}=\begin{bmatrix}3\\2\\3\end{bmatrix}.$$

第一轮，第一列中绝对值最大的是第三行的 2，把第三行换到第一行，工作矩阵的行依次为 $(2,0,1)$、$(1,1,0)$、$(0,2,1)$。乘子为 $l_{2,1}=\frac{1}{2}$、$l_{3,1}=0$，消元后两行变成 $(0,1,-\frac{1}{2})$ 和 $(0,2,1)$。

第二轮，第二列剩余元素为 1 与 2，主元在第三行，交换后两行；同时把 $\boldsymbol{L}$ 第一列中已存的乘子 $\frac{1}{2}$ 与 0 交换，使 $l_{2,1}=0$、$l_{3,1}=\frac{1}{2}$。再以 2 为主元，乘子 $l_{3,2}=\frac{1}{2}$，第三行变为 $(0,1,-\frac{1}{2})-\frac{1}{2}(0,2,1)=(0,0,-1)$。于是

$$\boldsymbol{L}=\begin{bmatrix}1&0&0\\0&1&0\\\frac{1}{2}&\frac{1}{2}&1\end{bmatrix},\qquad \boldsymbol{U}=\begin{bmatrix}2&0&1\\0&2&1\\0&0&-1\end{bmatrix},$$

$\boldsymbol{PA}$ 的三行依次是 $\boldsymbol{A}$ 的第三、一、二行。逐行核对：$\boldsymbol{LU}$ 的第三行为 $\frac{1}{2}(2,0,1)+\frac{1}{2}(0,2,1)+(0,0,-1)=(1,1,0)$，正是 $\boldsymbol{A}$ 的第二行；若忘记交换已存乘子，$\boldsymbol{L}$ 的第二行会是 $(\frac{1}{2},1,0)$，乘出的第二行 $(1,2,\frac{3}{2})$ 不再是 $\boldsymbol{PA}$ 的任何一行。

右端经两次交换为 $\boldsymbol{c}=\boldsymbol{Pb}=(3,3,2)^{\top}$。前代依次得 $y_1=3$、$y_2=3$、$y_3=2-\frac{3}{2}-\frac{3}{2}=-1$；回代得 $x_3=(-1)/(-1)=1$、$x_2=(3-1)/2=1$、$x_1=(3-1)/2=1$。代回原方程，$\boldsymbol{Ax}=(3,2,3)^{\top}=\boldsymbol{b}$。

10.1.3 算法分析

正确性　算法能否进行，取决于每一步是否有非零主元。部分选主元对任何非奇异矩阵都能进行；不选主元时则需要额外的条件，下面的定理给出这一条件，并说明分解在什么意义下唯一。

定理 10.3　LU 分解的存在与唯一　设 $\boldsymbol{A}\in\mathbb{R}^{d\times d}$，记 $\boldsymbol{A}_k$ 为其左上角 k 阶子矩阵。

1. 若 $\boldsymbol{A}$ 非奇异，则部分选主元消元的每一步都有非零主元，给出置换矩阵 $\boldsymbol{P}$、元素满足 $|l_{i,j}|\le 1$ 的单位下三角矩阵 $\boldsymbol{L}$ 与非奇异上三角矩阵 $\boldsymbol{U}$，使 $\boldsymbol{PA}=\boldsymbol{LU}$。
2. 不选主元时，$\boldsymbol{A}=\boldsymbol{LU}$（$\boldsymbol{L}$ 单位下三角，$\boldsymbol{U}$ 非奇异上三角）存在，当且仅当 $\det\boldsymbol{A}_k\neq 0$ 对 $k=1,\dots,d$ 都成立；此时分解唯一。

证明　(1) 第 k 步开始时 $\boldsymbol{W}=\boldsymbol{M}\boldsymbol{A}$，其中 $\boldsymbol{M}$ 是此前各次行交换与消元矩阵的乘积，可逆；$\boldsymbol{W}$ 的前 $k-1$ 列已是对角元非零的上三角形状。若第 k 列从第 k 行起全为零，$\boldsymbol{W}$ 的前 k 列就都落在 $\operatorname{span}\{\boldsymbol{e}_1,\dots,\boldsymbol{e}_{k-1}\}$ 中而线性相关，$\boldsymbol{A}=\boldsymbol{M}^{-1}\boldsymbol{W}$ 随之奇异，矛盾。选出的主元绝对值最大，故 $|l_{i,k}|\le 1$。由主要思想中的推导，全部置换移到右侧后得到 $\boldsymbol{P}\boldsymbol{A}=\boldsymbol{L}\boldsymbol{U}$。

(2) 若 $\boldsymbol{A}=\boldsymbol{L}\boldsymbol{U}$，由三角形状，左上角 k 阶块满足 $\boldsymbol{A}_k=\boldsymbol{L}_k\boldsymbol{U}_k$，故 $\det\boldsymbol{A}_k=\prod_{i\le k}u_{i,i}\neq 0$。反之，设各 $\det\boldsymbol{A}_k\neq 0$，用归纳法说明不选主元时第 k 个主元非零：前 $k-1$ 步只用了单位下三角的消元矩阵，$\boldsymbol{W}=\boldsymbol{M}\boldsymbol{A}$ 中 $\boldsymbol{M}$ 单位下三角，于是 $\boldsymbol{W}_k=\boldsymbol{M}_k\boldsymbol{A}_k$，$\det\boldsymbol{W}_k=\det\boldsymbol{A}_k\neq 0$；而 $\boldsymbol{W}_k$ 是上三角矩阵，前 $k-1$ 个对角元非零，所以 $w_{k,k}\neq 0$。唯一性：若 $\boldsymbol{L}_1\boldsymbol{U}_1=\boldsymbol{L}_2\boldsymbol{U}_2$，则 $\boldsymbol{L}_2^{-1}\boldsymbol{L}_1=\boldsymbol{U}_2\boldsymbol{U}_1^{-1}$，左边单位下三角，右边上三角，只能都等于 $\boldsymbol{I}_d$。 ■

定理的第一部分说明前代与回代给出的正是原方程的解：行交换只重排方程，不改变解。第二部分中的条件不能仅由 $\boldsymbol{A}$ 非奇异推出，例如 $\left[\begin{smallmatrix}0&1\\1&1\end{smallmatrix}\right]$ 可逆，第一个主元却为零。

主元增长与数值敏感度　精确算术中任何非零主元都可以用，选主元是为有限精度服务的。主元很小时乘子很大，尾块更新 $w_{i,j}-l_{i,k}w_{k,j}$ 会产生远大于原始元素的数，原始元素的信息在舍入中被淹没。衡量这种现象的是**增长因子**

$$\rho=\frac{\max_{i,j,k}|w_{i,j}^{(k)}|}{\max_{i,j}|a_{i,j}|},$$

其中 $w_{i,j}^{(k)}$ 是第 k 轮之后工作矩阵的元素。部分选主元使 $|l_{i,k}|\le 1$，每轮元素的绝对值至多翻倍，所以 $\rho\le 2^{d-1}$；这个上界可以达到，但在实际计算中极少出现，增长因子通常很小。LU 的后向误差与 ρ 成正比，这一误差界及其解释见第 14.1.2节。

计算代价　第 k 步更新 $(d-k)^2$ 个元素，一次稠密分解约需 $\frac{2}{3}d^3$ 次浮点运算；此后每个新右端只需一次前代和一次回代，约 $2d^2$ 次运算。因此求解 $\boldsymbol{A}\boldsymbol{X}=\boldsymbol{B}$ 的 s 个右端总共约需 $\frac{2}{3}d^3+2sd^2$ 次运算，远少于对每个右端重新消元。稀疏矩阵消元时，原来为零的位置会产生非零元，称为**填充**（fill-in），其多少取决于消元顺序，估计代价时须一并考虑。

10.2 Cholesky 分解

对称正定矩阵是最常见的特殊结构，例如正规方程、二次型的 Hessian 矩阵和协方差矩阵。利用对称性，可以只构造一个三角因子，运算和存储都减少一半；正定性则保证构造过程中的每次开方和除法都能进行。

10.2.1 主要思想

设 $\boldsymbol{A} \in \mathbb{R}^{d\times d}$ 实对称正定，$\boldsymbol{b} \in \mathbb{R}^{d}$，要求精确解 $\boldsymbol{x}_\star$。核心思想是把 LU 中的两个三角因子取成互为转置的形式，即**Cholesky 分解**（Cholesky decomposition）

$$\boldsymbol{A} = \boldsymbol{L}\boldsymbol{L}^{\top}, \tag{10.4}$$

其中 $\boldsymbol{L}$ 是对角元为正的下三角矩阵。这样只需构造一个因子 $\boldsymbol{L}$，原方程 $\boldsymbol{L}(\boldsymbol{L}^{\top}\boldsymbol{x}) = \boldsymbol{b}$ 就化为两个三角方程，用前代和回代各解一次。

逐元素等式　构造 $\boldsymbol{L}$ 的公式来自比较 $\boldsymbol{A}$ 与 $\boldsymbol{L}\boldsymbol{L}^{\top}$ 的元素。$\boldsymbol{L}\boldsymbol{L}^{\top}$ 的 (i,j) 元是 $\boldsymbol{L}$ 的第 i 行与第 j 行的内积，因三角结构，$k > \min(i,j)$ 的项为零：

$$a_{i,j} = \sum_{k=1}^{\min(i,j)} l_{i,k} l_{j,k}.$$

三阶时，下三角部分的六个等式依次是

$$\begin{aligned} a_{1,1} &= l_{1,1}^2, \quad a_{2,1} = l_{2,1}l_{1,1}, \quad a_{3,1} = l_{3,1}l_{1,1}, \\ a_{2,2} &= l_{2,1}^2 + l_{2,2}^2, \quad a_{3,2} = l_{3,1}l_{2,1} + l_{3,2}l_{2,2}, \\ a_{3,3} &= l_{3,1}^2 + l_{3,2}^2 + l_{3,3}^2. \end{aligned}$$

按第一列、第二列、第三列的次序读这些等式，每个等式恰好只含一个新的未知元素，其余都已算出。

逐列递推　一般地，在第 j 列先取 $i = j$，把已完成列的贡献移到右侧，得 $l_{j,j}^2 = a_{j,j} - \sum_{k<j} l_{j,k}^2$；按正对角的约定取正根。再对同列下方的 $i > j$，把 $a_{i,j} = \sum_{k<j} l_{i,k}l_{j,k} + l_{i,j}l_{j,j}$ 中已知的部分移项，除以刚算出的 $l_{j,j}$。合起来，对 $j = 1, \dots, d$ 逐列计算

$$\begin{aligned} l_{j,j} &= \sqrt{a_{j,j} - \sum_{k<j} l_{j,k}^2}, \\ l_{i,j} &= \frac{a_{i,j} - \sum_{k<j} l_{i,k}l_{j,k}}{l_{j,j}} \quad (i > j), \end{aligned} \tag{10.5}$$

$j = 1$ 时两个和式都是空和。计算的依赖方向是：先算本列对角元，再算其下全部元素，然后进入下一列；计算只读取 $\boldsymbol{A}$ 的下三角部分。各列完成

后，上述等式覆盖了下三角的全部位置，而 $\boldsymbol{A}$ 与 $\boldsymbol{L}\boldsymbol{L}^{\top}$ 都对称，上三角的等式自动成立，不需要另外计算。

开方量为什么为正　式 (10.5)要求每个开方量为正，这正是正定性所保证的。设前 $j-1$ 列已经算出，记左上角 $j-1$ 阶块为 $\boldsymbol{B}$，第 j 列在它上方的部分为 $\boldsymbol{c}$，于是 $\boldsymbol{B}=\boldsymbol{L}_{j-1}\boldsymbol{L}_{j-1}^{\top}$，其中 $\boldsymbol{L}_{j-1}$ 是 $\boldsymbol{L}$ 的左上角块。第 j 行已算出的前 $j-1$ 个元素记为 $\boldsymbol{\ell}$，由 $a_{k,j}$（$k<j$）的等式得 $\boldsymbol{L}_{j-1}\boldsymbol{\ell}=\boldsymbol{c}$，所以

$$\sum_{k<j} l_{j,k}^{2}=\|\boldsymbol{\ell}\|_{2}^{2}=\boldsymbol{c}^{\top}\boldsymbol{L}_{j-1}^{-\top}\boldsymbol{L}_{j-1}^{-1}\boldsymbol{c}=\boldsymbol{c}^{\top}\boldsymbol{B}^{-1}\boldsymbol{c}.$$

开方量因而是 $a_{j,j}-\boldsymbol{c}^{\top}\boldsymbol{B}^{-1}\boldsymbol{c}$，即左上角 j 阶块关于 $\boldsymbol{B}$ 的 Schur 补。取前 j 个分量为 $(-\boldsymbol{B}^{-1}\boldsymbol{c},1)$、其余分量为零的向量 $\boldsymbol{w}$，直接展开得

$$\boldsymbol{w}^{\top}\boldsymbol{A}\boldsymbol{w}=\boldsymbol{c}^{\top}\boldsymbol{B}^{-1}\boldsymbol{c}-2\boldsymbol{c}^{\top}\boldsymbol{B}^{-1}\boldsymbol{c}+a_{j,j}=a_{j,j}-\boldsymbol{c}^{\top}\boldsymbol{B}^{-1}\boldsymbol{c},$$

而 $\boldsymbol{w}\neq\boldsymbol{0}$，正定性给出它严格为正。所以正定性不仅是输入的标签，它在每一列都以“开方量为正”的形式被使用。

两次三角求解　最后由 $\boldsymbol{L}(\boldsymbol{L}^{\top}\boldsymbol{x})=\boldsymbol{b}$，先用前代 (10.2)求解 $\boldsymbol{L}\boldsymbol{y}=\boldsymbol{b}$，再用回代 (10.3)求解 $\boldsymbol{L}^{\top}\boldsymbol{x}=\boldsymbol{y}$，即

$$y_i=\frac{b_i-\sum_{k<i} l_{i,k}y_k}{l_{i,i}},\qquad x_i=\frac{y_i-\sum_{k>i} l_{k,i}x_k}{l_{i,i}}.$$

与 LU 不同，这里 $l_{i,i}$ 一般不等于 1，除法要保留；$\boldsymbol{L}^{\top}$ 的上三角元素 $(\boldsymbol{L}^{\top})_{i,k}=l_{k,i}$ 直接从 $\boldsymbol{L}$ 读出，同一个因子分别按正序和逆序读取，无需显式计算 $\boldsymbol{A}^{-1}$。

10.2.2　算法实现

逐列分解　输入实对称正定的 $\boldsymbol{A}$ 和 $\boldsymbol{b}$，把 $\boldsymbol{L}$ 初始化为零矩阵。对 $j=1,\dots,d$，先累计开方量 $\delta_j=a_{j,j}-\sum_{k<j} l_{j,k}^{2}$，检查 $\delta_j>0$ 后令 $l_{j,j}=\sqrt{\delta_j}$；再对 $i=j+1,\dots,d$ 累计列内乘积和，按式 (10.5)计算 $l_{i,j}$。

若某个 $\delta_j\le 0$，就停止并报告：要么输入不满足正定条件，要么矩阵接近奇异，舍入误差已使当前计算不可靠。这时不能擅自取绝对值继续，也不能把小量截为零后当作 Cholesky 分解；对称不定问题改用第 10.3节的分块 LDL 分解，半正定或秩亏问题按求解目标改用第 10.8节的 SVD 求解或第 14章的正则化。

两次三角求解　分解完成后，前代求解 $\boldsymbol{L}\boldsymbol{y}=\boldsymbol{b}$，回代求解 $\boldsymbol{L}^{\top}\boldsymbol{x}=\boldsymbol{y}$，输出 $\boldsymbol{x}$。实际程序只保存下三角因子；多个右端复用同一因子。

示例 10.4　Cholesky 分解的三步计算　取

$$A=\begin{bmatrix}4&2&2\\2&5&3\\2&3&6\end{bmatrix},\qquad b=\begin{bmatrix}8\\10\\11\end{bmatrix}.$$

这个矩阵对称正定，可以用 Cholesky 分解。逐列计算：第一列 $l_{1,1}=\sqrt{4}=2$，$l_{2,1}=l_{3,1}=2/2=1$；第二列先扣除第一列的贡献再开方，$l_{2,2}=\sqrt{5-1}=2$，$l_{3,2}=(3-1\cdot 1)/2=1$；最后 $l_{3,3}=\sqrt{6-1-1}=2$，即

$$L=\begin{bmatrix}2&0&0\\1&2&0\\1&1&2\end{bmatrix}.$$

只有一个因子，前代用 L，回代用它的转置。前代解 $Ly=b$，得 $y_1=8/2=4$，$y_2=(10-4)/2=3$，$y_3=(11-4-3)/2=2$；回代解 $L^{\top}x=y$，得 $x_3=2/2=1$，$x_2=(3-1)/2=1$，$x_1=(4-1-1)/2=1$。所以 $x=(1,1,1)^{\top}$，代回可验 $Ax=b$。

上例各元素都为正。下例含负的非对角元，用来检查递推中各项的符号，并分别核验分解残差和求解残差。

示例 10.5　含负元素的 Cholesky 分解与核验　取

$$A=\begin{bmatrix}4&12&-16\\12&37&-43\\-16&-43&98\end{bmatrix},\qquad b=\begin{bmatrix}0\\6\\39\end{bmatrix}.$$

第一列：$l_{1,1}=\sqrt{4}=2$，$l_{2,1}=12/2=6$，$l_{3,1}=-16/2=-8$。第二列：开方量 $37-6^2=1$，所以 $l_{2,2}=1$；$l_{3,2}=(-43-(-8)\cdot 6)/1=5$。第三列：开方量 $98-(-8)^2-5^2=9$，所以 $l_{3,3}=3$。于是

$$L=\begin{bmatrix}2&0&0\\6&1&0\\-8&5&3\end{bmatrix},$$

逐项相乘可验 $LL^{\top}=A$，例如 $(3,2)$ 元为 $(-8)\cdot 6+5\cdot 1=-43$。

前代依次得 $y_1=0/2=0$，$y_2=(6-6\cdot 0)/1=6$，$y_3=(39-(-8)\cdot 0-5\cdot 6)/3=3$；回代解 $L^{\top}x=y$，得 $x_3=3/3=1$，$x_2=(6-5\cdot 1)/1=1$，$x_1=(0-6\cdot 1-(-8)\cdot 1)/2=1$。最后用原始的 A 和 b 重算 $Ax-b$，

本例为零。分解残差 $\boldsymbol{A}-\boldsymbol{L}\boldsymbol{L}^{\top}$ 检查因子，求解残差 $\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}$ 检查两次三角求解，二者要分别核验。

10.2.3 算法分析

正确性　逐列构造能否进行，取决于每次开方的数是否为正。主要思想中已经看到正定性保证了这一点；下面的定理进一步说明正定性也是分解存在的必要条件。

定理 10.6　Cholesky 分解的存在与唯一　设 $\boldsymbol{A}\in\mathbb{R}^{d\times d}$ 对称。存在对角元为正的下三角矩阵 $\boldsymbol{L}$ 使 $\boldsymbol{A}=\boldsymbol{L}\boldsymbol{L}^{\top}$，当且仅当 $\boldsymbol{A}\succ 0$；此时 $\boldsymbol{L}$ 唯一，并由式 (10.5)给出。

证明　必要性：$\boldsymbol{L}$ 的对角元为正，故可逆；对非零 $\boldsymbol{v}$ 有 $\boldsymbol{v}^{\top}\boldsymbol{A}\boldsymbol{v}=\|\boldsymbol{L}^{\top}\boldsymbol{v}\|_2^2>0$。充分性对阶数归纳。把 $\boldsymbol{A}$ 按首行首列分块为 $\left[\begin{smallmatrix} a_{1,1} & \boldsymbol{a}^{\top} \\ \boldsymbol{a} & \boldsymbol{A}_{22}\end{smallmatrix}\right]$，正定性给出 $a_{1,1}=\boldsymbol{e}_1^{\top}\boldsymbol{A}\boldsymbol{e}_1>0$，所以 $l_{1,1}=\sqrt{a_{1,1}}$ 有定义，第一列其余元素为 $\boldsymbol{a}/l_{1,1}$。对 $\boldsymbol{v}=(v_1,\boldsymbol{w}^{\top})^{\top}$ 关于首变量配方，

$$\boldsymbol{v}^{\top}\boldsymbol{A}\boldsymbol{v}=a_{1,1}\Big(v_1+\frac{\boldsymbol{a}^{\top}\boldsymbol{w}}{a_{1,1}}\Big)^2+\boldsymbol{w}^{\top}\Big(\boldsymbol{A}_{22}-\frac{\boldsymbol{a}\boldsymbol{a}^{\top}}{a_{1,1}}\Big)\boldsymbol{w}.$$

对任意非零 $\boldsymbol{w}$ 取 $v_1=-\boldsymbol{a}^{\top}\boldsymbol{w}/a_{1,1}$，左边为正，故剩余矩阵 $\boldsymbol{A}_{22}-\boldsymbol{a}\boldsymbol{a}^{\top}/a_{1,1}$ 仍正定；后面各列的计算正是对它重复同样的步骤，由归纳假设每一步开方的数都为正。唯一性：对角元取正后，式 (10.5)逐个唯一地确定每个元素。 ■

由 $\boldsymbol{A}=\boldsymbol{L}\boldsymbol{L}^{\top}$，算出的 $\boldsymbol{x}$ 满足 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{L}(\boldsymbol{L}^{\top}\boldsymbol{x})=\boldsymbol{L}\boldsymbol{y}=\boldsymbol{b}$。

数值敏感度　$a_{j,j}=\sum_{k\le j}l_{j,k}^2$ 给出 $|l_{j,k}|\le\sqrt{a_{j,j}}$，因子的元素不会增长，因此分解不选主元也是后向稳定的（第 14.1.2节）；解的误差仍由 $\boldsymbol{A}$ 的条件数决定（第 7.1.3节）。还要区分数学上的正定与有限精度下的可计算性：$\boldsymbol{A}$ 正定但最小特征值相对于 $\|\boldsymbol{A}\|_2$ 极小时，开方量本身很小，舍入误差可能使它算成零或负数，算法在一个本应正定的矩阵上报告失败。这种失败提示问题接近奇异，处理办法属于第 14章。

计算代价　稠密分解约需 $\frac{1}{3}d^3$ 次运算，是 LU 的一半，存储也只需一个三角因子；每个右端的两次三角求解约需 $2d^2$ 次运算。

10.3 分块 LDL 分解

对称但不定的矩阵也很常见，例如带约束的二次问题给出的鞍点系统。这时 Cholesky 分解的开方量可能为负，而直接用 LU 又浪费了对称性。分块 LDL 分解不开方，并在必要时用二阶主元块，使对称结构和非奇异方程的可解性同时得到保留。

10.3.1 主要思想

设 $\boldsymbol{A} \in \mathbb{R}^{d\times d}$ 实对称非奇异，但不一定正定，$\boldsymbol{b} \in \mathbb{R}^{d}$，要求唯一精确解 $\boldsymbol{x}_\star$。目标是构造**分块 LDL 分解**

$$\boldsymbol{P}\boldsymbol{A}\boldsymbol{P}^{\top} = \boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\top}, \tag{10.6}$$

其中 $\boldsymbol{P}$ 是置换矩阵，$\boldsymbol{L}$ 是单位下三角矩阵，$\boldsymbol{D}$ 由可逆的一阶和二阶对称块组成。对称置换同时交换行与列，矩阵保持对称。

标量主元的递推 先看无需交换、每个主元都是非零标量的情形。设 $\boldsymbol{A} = \boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\top}$，$\boldsymbol{D} = \operatorname{diag}(d_1, \dots, d_d)$，比较 (i, j) 元（$i \ge j$）得 $a_{i,j} = \sum_{k\le j} l_{i,k} d_k l_{j,k}$。与 Cholesky 的推导相同，逐列移项得到

$$d_j = a_{j,j} - \sum_{k<j} l_{j,k}^2 d_k, \qquad l_{i,j} = \frac{a_{i,j} - \sum_{k<j} l_{i,k} d_k l_{j,k}}{d_j} \quad (i > j).$$

这里不对 d_j 开方，所以 d_j 可以为负，主元的正负号保留在 $\boldsymbol{D}$ 中；但仍要除以 d_j，零主元会使递推中断。

为什么需要二阶块 零主元并不意味着矩阵奇异。例如 $\left[\begin{smallmatrix} 0 & 1 \\ 1 & 0 \end{smallmatrix}\right]$ 可逆，但两个对角元都是零。对称置换只把对角元换到别的对角位置，所以无论怎样对称交换，第一个标量主元都是零；若据此判定矩阵奇异就会出错。把这两行两列合成一个可逆的二阶块作主元，才保留方程的可解性。

一步块消元 设交换后当前剩余矩阵写成

$$\begin{bmatrix} \boldsymbol{E} & \boldsymbol{C}^{\top} \\ \boldsymbol{C} & \boldsymbol{F} \end{bmatrix},$$

其中 $\boldsymbol{E}$ 是选出的一阶或二阶可逆对称块。要找乘子块 $\boldsymbol{M}$ 与新的剩余矩阵 $\boldsymbol{S}$，使

$$\begin{bmatrix} \boldsymbol{E} & \boldsymbol{C}^{\top} \\ \boldsymbol{C} & \boldsymbol{F} \end{bmatrix} = \begin{bmatrix} \boldsymbol{I} & \boldsymbol{0} \\ \boldsymbol{M} & \boldsymbol{I} \end{bmatrix} \begin{bmatrix} \boldsymbol{E} & \boldsymbol{0} \\ \boldsymbol{0} & \boldsymbol{S} \end{bmatrix} \begin{bmatrix} \boldsymbol{I} & \boldsymbol{M}^{\top} \\ \boldsymbol{0} & \boldsymbol{I} \end{bmatrix}.$$

右侧乘开后左下块为 $\boldsymbol{ME}$，右下块为 $\boldsymbol{MEM}^{\top}+\boldsymbol{S}$。令左下块等于 $\boldsymbol{C}$，得 $\boldsymbol{ME}=\boldsymbol{C}$，即 $\boldsymbol{M}=\boldsymbol{CE}^{-1}$；令右下块等于 $\boldsymbol{F}$，并用 $\boldsymbol{E}$ 对称化简 $\boldsymbol{MEM}^{\top}=\boldsymbol{CE}^{-1}\boldsymbol{C}^{\top}=\boldsymbol{MC}^{\top}$，得

$$\boldsymbol{S}=\boldsymbol{F}-\boldsymbol{MC}^{\top}=\boldsymbol{F}-\boldsymbol{CE}^{-1}\boldsymbol{C}^{\top}.$$

实际计算时通过求解一阶或二阶方程 $\boldsymbol{ME}=\boldsymbol{C}$ 形成 $\boldsymbol{M}$，不显式求逆。

分解与求解　对 $\boldsymbol{S}$ 重复同样的步骤，并把每一轮的对称置换累积起来，就得到式 (10.6)。由它，$\boldsymbol{Ax}=\boldsymbol{b}$ 等价于 $\boldsymbol{LDL}^{\top}(\boldsymbol{Px})=\boldsymbol{Pb}$，求解依次为 $\boldsymbol{Ly}=\boldsymbol{Pb}$、$\boldsymbol{Dz}=\boldsymbol{y}$、$\boldsymbol{L}^{\top}\boldsymbol{w}=\boldsymbol{z}$ 和 $\boldsymbol{x}=\boldsymbol{P}^{\top}\boldsymbol{w}$。中间一步按 $\boldsymbol{D}$ 的对角块求解，而不是逐元素相除。

10.3.2 算法实现

需要预先选定的规则是选块策略。为使给定数据下的计算可以复算，这里采用一个精确算术下可执行的代数规则。设当前剩余矩阵的首个对角元为 $w_{k,k}$：若 $w_{k,k}\neq 0$，取它作一阶块；若 $w_{k,k}=0$，在第 k 列下方找绝对值最大的非零元素 $w_{p,k}$（绝对值相同时取行号最小者），把第 p 行与第 p 列对称地交换到第 $k+1$ 个位置，取二阶块

$$\boldsymbol{E}=\begin{bmatrix} 0 & w_{p,k} \\ w_{p,k} & w_{p,p} \end{bmatrix},$$

它的行列式为 $-w_{p,k}^{2}\neq 0$，所以可逆；若第 k 列下方也全为零，报告非奇异分支失败。这一规则只保证构造能够进行，并不保证数值稳定。

选块与对称交换　初始化 $\boldsymbol{W}=\boldsymbol{A}$、$\boldsymbol{L}=\boldsymbol{I}_d$、$\boldsymbol{P}=\boldsymbol{I}_d$，$\boldsymbol{D}$ 为空。每一轮按选块规则确定一阶或二阶块，需要交换时同时交换 $\boldsymbol{W}$ 的相应行与列，对 $\boldsymbol{P}$ 作同样的行交换，$\boldsymbol{L}$ 中已经算出的乘子也交换相应两行。交换后把当前剩余矩阵写成主要思想中的分块形式，$\boldsymbol{E}$ 为选出的主元块。

块消元　逐行求解一阶或二阶方程 $\boldsymbol{ME}=\boldsymbol{C}$ 得到乘子块 $\boldsymbol{M}$。把 $\boldsymbol{M}$ 写入 $\boldsymbol{L}$ 中主元块下方的位置，把 $\boldsymbol{E}$ 放入 $\boldsymbol{D}$ 的下一个对角块，再把剩余矩阵更新为

$$\boldsymbol{F}-\boldsymbol{MC}^{\top}.$$

它仍是对称矩阵，只需计算下三角部分。下一轮的起点前移的步长等于本轮主元块的阶数；对更小的剩余矩阵重复选块与消元，直到剩余矩阵为空。

三段求解 先把右端重排为 $\boldsymbol{c} = \boldsymbol{P}\boldsymbol{b}$，用前代求解 $\boldsymbol{L}\boldsymbol{y} = \boldsymbol{c}$。接着按 $\boldsymbol{D}$ 的对角块逐个求解 $\boldsymbol{D}\boldsymbol{z} = \boldsymbol{y}$：一阶块直接作标量除法；对二阶块 $\left[\begin{smallmatrix} e_{1,1} & e_{1,2} \\ e_{1,2} & e_{2,2} \end{smallmatrix}\right]$，把它对应的两个分量记为 (y_1, y_2) 与 (z_1, z_2)，由二阶逆矩阵公式得

$$z_1 = \frac{e_{2,2}y_1 - e_{1,2}y_2}{e_{1,1}e_{2,2} - e_{1,2}^2},$$
$$z_2 = \frac{e_{1,1}y_2 - e_{1,2}y_1}{e_{1,1}e_{2,2} - e_{1,2}^2},$$

分母因所选块可逆而非零。最后用回代求解 $\boldsymbol{L}^{\mathsf{T}}\boldsymbol{w} = \boldsymbol{z}$，此时 $\boldsymbol{w} = \boldsymbol{P}\boldsymbol{x}$，再按 $\boldsymbol{x} = \boldsymbol{P}^{\mathsf{T}}\boldsymbol{w}$ 恢复未知量的原次序，得到所求的 $\boldsymbol{x}$。

示例 10.7　需要二阶块的 LDL 分解　取

$$\boldsymbol{A} = \begin{bmatrix} 0 & 2 & 1 \\ 2 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}, \qquad \boldsymbol{b} = \begin{bmatrix} 3 \\ 3 \\ 2 \end{bmatrix}.$$

这个矩阵的对角元全为零，不能取一阶主元，Cholesky 分解也无从开始。第一列下方绝对值最大的元素是 $a_{2,1} = 2$，它已在第二个位置，所以 $\boldsymbol{P} = \boldsymbol{I}_3$，取二阶块 $\boldsymbol{E} = \left[\begin{smallmatrix} 0 & 2 \\ 2 & 0 \end{smallmatrix}\right]$，其余部分为 $\boldsymbol{C} = (1, 1)$、$\boldsymbol{F} = 0$。由 $\boldsymbol{M}\boldsymbol{E} = \boldsymbol{C}$ 得 $\boldsymbol{M} = (\frac{1}{2}, \frac{1}{2})$，剩余矩阵为 $0 - \boldsymbol{M}\boldsymbol{C}^{\mathsf{T}} = -1$，于是 $\boldsymbol{D} = \operatorname{diag}(\boldsymbol{E}, -1)$，$\boldsymbol{L}$ 的第三行为 $(\frac{1}{2}, \frac{1}{2}, 1)$。

求解分三段。前代得 $\boldsymbol{y} = (3, 3, 2 - \frac{3}{2} - \frac{3}{2})^{\mathsf{T}} = (3, 3, -1)^{\mathsf{T}}$；再按 $\boldsymbol{D}$ 的块结构求解，二阶块给出 $z_1 = z_2 = (0 - 6)/(-4) = \frac{3}{2}$，一阶块给出 $z_3 = 1$；最后回代，得 $w_3 = 1$，$w_2 = w_1 = \frac{3}{2} - \frac{1}{2} = 1$。因此 $\boldsymbol{x} = (1, 1, 1)^{\mathsf{T}}$，代回可验 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$。

上例三个对角元都是零。下例的第三个对角元非零，二阶块之后的剩余矩阵为负数，用来同时观察二阶块的求解和负主元的保留。

示例 10.8　二阶块后接负主元　取

$$\boldsymbol{A} = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 2 \\ 1 & 2 & 3 \end{bmatrix}, \qquad \boldsymbol{b} = \begin{bmatrix} 2 \\ 3 \\ 6 \end{bmatrix}.$$

首个对角元为零，第一列下方绝对值最大的元素是 $a_{2,1} = 1$（与 $a_{3,1}$ 相同，取行号较小者），无需交换，取 $\boldsymbol{E} = \left[\begin{smallmatrix} 0 & 1 \\ 1 & 0 \end{smallmatrix}\right]$，$\boldsymbol{C} = (1, 2)$，$\boldsymbol{F} = 3$。

设 $\boldsymbol{M}=(m_1,m_2)$，则 $\boldsymbol{M}\boldsymbol{E}=(m_2,m_1)=(1,2)$，得 $\boldsymbol{M}=(2,1)$；剩余矩阵为 $3-(2,1)(1,2)^{\top}=-1$。因此

$$\boldsymbol{L}=\begin{bmatrix}1&0&0\\0&1&0\\2&1&1\end{bmatrix},\qquad \boldsymbol{D}=\begin{bmatrix}0&1&0\\1&0&0\\0&0&-1\end{bmatrix}.$$

前代得 $\boldsymbol{y}=(2,3,6-2\cdot 2-1\cdot 3)^{\top}=(2,3,-1)^{\top}$。二阶块方程 $z_2=2$、$z_1=3$，一阶块给出 $z_3=(-1)/(-1)=1$，即 $\boldsymbol{z}=(3,2,1)^{\top}$。回代得 $w_3=1$，$w_2=2-1\cdot 1=1$，$w_1=3-2\cdot 1=1$；本例无需置换，所以 $\boldsymbol{x}=\boldsymbol{w}=(1,1,1)^{\top}$。逐项可验 $\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\top}=\boldsymbol{A}$ 与 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$。最后出现的两个 -1 含义不同：二阶块的行列式 $\det\boldsymbol{E}=-1$ 非零，说明所选块可逆、消元可以进行；末尾主元 -1 非零，则与 $\boldsymbol{E}$ 一起保证整个矩阵非奇异，$\det\boldsymbol{A}=\det\boldsymbol{E}\cdot(-1)=1$。

10.3.3 算法分析

正确性　主要思想中的一步块消元恒等式可以乘开验证，只用到 $\boldsymbol{M}\boldsymbol{E}=\boldsymbol{C}$ 和 $\boldsymbol{E}^{\top}=\boldsymbol{E}$。两侧单位块三角因子的行列式为 1，对称置换 $\boldsymbol{P}\boldsymbol{W}\boldsymbol{P}^{\top}$ 也不改变行列式，所以每一轮的剩余矩阵都与 $\boldsymbol{A}$ 一样非奇异。选块规则因此总能进行：若当前首个对角元为零且第 k 列下方也全为零，则由对称性剩余矩阵的首行首列全为零，它将是奇异的，矛盾。逐轮累积对称置换与乘子即得式 (10.6)，前代、块对角求解、回代与还原次序因而给出原方程的解。$\boldsymbol{D}$ 中的负主元或不定二阶块只说明 $\boldsymbol{A}$ 有使二次型为负的方向，并不妨碍可逆求解。

数值敏感度　要区分两类规则：上面的选块规则保证代数构造可以进行，稳定的主元策略则要控制数值误差。存在可逆主元并不等于稳定：主元块相对很小时乘子很大，剩余矩阵的元素随之增长，与 LU 中的主元增长是同一现象。实用的选块策略要控制这种增长，Bunch–Kaufman 策略就是一例，它按当前对角元与所在列最大非对角元的相对大小，决定取一阶块还是二阶块。

计算代价　稠密计算约需 $\frac{1}{3}d^3$ 次运算，存储约 $\frac{1}{2}d^2$ 个元素，利用对称性比直接用 LU 减少一半。

10.4 分块消元

许多方程的未知量天然分成两组，例如网格上的内部点与边界点，或模型参数与约束乘子。若其中一组对应的主块容易求解，就可以先消去这一

组，只对另一组解一个较小的方程。分块消元把前三节的分解当作子过程使用。

10.4.1 主要思想

设非奇异矩阵 $\boldsymbol{A}$、右端 $\boldsymbol{b}$ 与待求的 $\boldsymbol{x}$ 按两组未知量分块为

$$\boldsymbol{A}=\begin{bmatrix}\boldsymbol{B} & \boldsymbol{C}\\ \boldsymbol{D} & \boldsymbol{E}\end{bmatrix},\quad \boldsymbol{b}=\begin{bmatrix}\boldsymbol{f}\\ \boldsymbol{g}\end{bmatrix},\quad \boldsymbol{x}=\begin{bmatrix}\boldsymbol{u}\\ \boldsymbol{v}\end{bmatrix},$$

其中 $\boldsymbol{B}\in\mathbb{R}^{p\times p}$ 可逆，$\boldsymbol{E}\in\mathbb{R}^{q\times q}$，$p+q=d$。分块只是输入 $\boldsymbol{A},\boldsymbol{b}$ 的一种写法，求解目标仍是精确解。

消去第一组未知量 第一组方程 $\boldsymbol{B}\boldsymbol{u}+\boldsymbol{C}\boldsymbol{v}=\boldsymbol{f}$ 给出 $\boldsymbol{u}=\boldsymbol{B}^{-1}\boldsymbol{f}-\boldsymbol{B}^{-1}\boldsymbol{C}\boldsymbol{v}$；这一消元顺序要求 $\boldsymbol{B}$ 可逆。为了不形成 $\boldsymbol{B}^{-1}$，引入 $\boldsymbol{B}\boldsymbol{z}=\boldsymbol{f}$ 与 $\boldsymbol{B}\boldsymbol{Z}=\boldsymbol{C}$ 的解 $\boldsymbol{z}\in\mathbb{R}^{p}$、$\boldsymbol{Z}\in\mathbb{R}^{p\times q}$，表达式改写为

$$\boldsymbol{u}=\boldsymbol{z}-\boldsymbol{Z}\boldsymbol{v}.$$

代入第二组方程 $\boldsymbol{D}\boldsymbol{u}+\boldsymbol{E}\boldsymbol{v}=\boldsymbol{g}$，得到约化方程

$$\boldsymbol{S}\boldsymbol{v}=\boldsymbol{h},\qquad \boldsymbol{S}=\boldsymbol{E}-\boldsymbol{D}\boldsymbol{Z},\quad \boldsymbol{h}=\boldsymbol{g}-\boldsymbol{D}\boldsymbol{z}. \tag{10.7}$$

q 阶矩阵 $\boldsymbol{S}=\boldsymbol{E}-\boldsymbol{D}\boldsymbol{B}^{-1}\boldsymbol{C}$ 称为 $\boldsymbol{A}$ 关于被消块 $\boldsymbol{B}$ 的Schur 补（Schur complement）。消去 $\boldsymbol{u}$ 时，系数和右端都要扣除经由 $\boldsymbol{u}$ 传来的部分，所以 $\boldsymbol{S}$ 与 $\boldsymbol{h}$ 必须同时形成。解出 $\boldsymbol{v}$ 后再由 $\boldsymbol{u}=\boldsymbol{z}-\boldsymbol{Z}\boldsymbol{v}$ 恢复第一组未知量。

块三角分解的解释 图 10.3把这一步画成增广分块矩阵的块行变换：第二块行减去 $\boldsymbol{D}\boldsymbol{B}^{-1}$ 乘第一块行后，左下块被消成零，右下块和右端分别换成 $\boldsymbol{S}$ 与 $\boldsymbol{h}$，剩下的是块上三角方程。用矩阵乘法写出来，就是第 10.1节 LU 分解的分块形式（见定理 10.11的证明）。小问题与原问题的关系也由此确定：$\boldsymbol{B}$ 可逆时，原矩阵非奇异当且仅当 $\boldsymbol{S}$ 非奇异；只找到一个可逆主块，并不能保证整个问题唯一可解。当 $\boldsymbol{A}$ 对称正定时，$\boldsymbol{B}$ 与 $\boldsymbol{S}$ 都对称正定，两次求解都可以复用 Cholesky 分解。

10.4.2 算法实现

用 $\boldsymbol{B}$ 的因子求解 先检查分块尺寸，并按 $\boldsymbol{B}$ 的结构调用前面的 LU 分解、Cholesky 分解或分块 LDL 分解，得到 $\boldsymbol{B}$ 的因子；已有分解时直接复用。$\boldsymbol{B}$ 只分解一次，然后用这组因子求解 $\boldsymbol{B}\boldsymbol{Z}=\boldsymbol{C}$ 的各列和 $\boldsymbol{B}\boldsymbol{z}=\boldsymbol{f}$。它们分别是 $\boldsymbol{B}^{-1}\boldsymbol{C}$ 与 $\boldsymbol{B}^{-1}\boldsymbol{f}$，但计算时只做前代与回代，不形成 $\boldsymbol{B}^{-1}$。

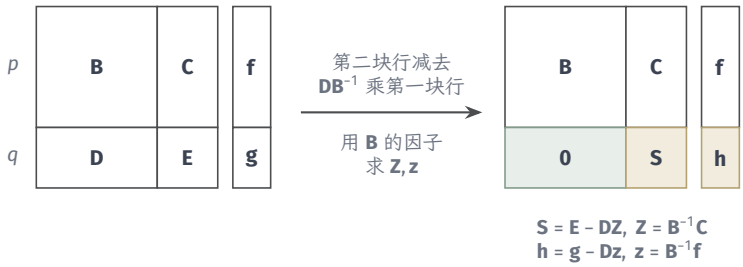


图 10.3 分块消元的结构。左为增广分块矩阵 $[\boldsymbol{A}\mid\boldsymbol{b}]$，两组未知量的个数分别为 p 与 q；第二块行减去 $\boldsymbol{D}\boldsymbol{B}^{-1}$ 乘第一块行后，左下块变为零（绿色），右下块与右端变为 Schur 补 $\boldsymbol{S}$ 及 $\boldsymbol{h}$（黄色）。$\boldsymbol{Z},\boldsymbol{z}$ 由 $\boldsymbol{B}$ 的因子求得，不形成 $\boldsymbol{B}^{-1}$。

形成并求解 Schur 补方程 按式 (10.7)形成 $\boldsymbol{S}=\boldsymbol{E}-\boldsymbol{D}\boldsymbol{Z}$ 与 $\boldsymbol{h}=\boldsymbol{g}-\boldsymbol{D}\boldsymbol{z}$，再按 $\boldsymbol{S}$ 的结构调用已有的直接法解出 $\boldsymbol{v}$。$\boldsymbol{A}$ 与 $\boldsymbol{B}$ 都非奇异时 $\boldsymbol{S}$ 也非奇异（见定理 10.11），这一步给出唯一结果。

恢复第一组未知量 最后计算 $\boldsymbol{u}=\boldsymbol{z}-\boldsymbol{Z}\boldsymbol{v}$，按原分组拼成 $\boldsymbol{x}=(\boldsymbol{u}^{\mathsf{T}},\boldsymbol{v}^{\mathsf{T}})^{\mathsf{T}}$，完成原方程的求解。

示例 10.9 二阶贯穿例的分块消元 先在二阶贯穿例上走一遍流程，这时每一块都是标量，各步一目了然。取 $\boldsymbol{A}=\left[\begin{smallmatrix}4&1\\1&3\end{smallmatrix}\right]$，$\boldsymbol{b}=(1,2)^{\mathsf{T}}$，令 $p=q=1$，即 $\boldsymbol{B}=4$，$\boldsymbol{C}=\boldsymbol{D}=1$，$\boldsymbol{E}=3$，$\boldsymbol{f}=1$，$\boldsymbol{g}=2$。第一步用 $\boldsymbol{B}$ 求解，得 $\boldsymbol{Z}=\frac{1}{4}$，$\boldsymbol{z}=\frac{1}{4}$。第二步形成约化方程的系数与右端，$\boldsymbol{S}=3-\frac{1}{4}=\frac{11}{4}$，$\boldsymbol{h}=2-\frac{1}{4}=\frac{7}{4}$。第三步解出 $v=\frac{7}{4}\big/\frac{11}{4}=\frac{7}{11}$，再恢复 $u=\frac{1}{4}-\frac{1}{4}\cdot\frac{7}{11}=\frac{1}{11}$。

代回可验 $4\cdot\frac{1}{11}+\frac{7}{11}=1$，$\frac{1}{11}+3\cdot\frac{7}{11}=2$。消元过程还顺带给出了行列式：$\det\boldsymbol{A}=\boldsymbol{B}\cdot\boldsymbol{S}=4\cdot\frac{11}{4}=11$，与下面定理中的公式 $\det\boldsymbol{A}=\det\boldsymbol{B}\det\boldsymbol{S}$ 一致。

二阶例子中 $\boldsymbol{B}$ 是标量，看不出“一次分解、多个右端”的安排。下例让被消块为二阶，$\boldsymbol{Z}$ 与 $\boldsymbol{z}$ 需要用同一个分解分别求出。

示例 10.10 消去两个未知量的三阶系统 取

$$\boldsymbol{A}=\begin{bmatrix}4&1&1\\1&3&0\\1&0&2\end{bmatrix},\qquad \boldsymbol{b}=\begin{bmatrix}6\\4\\3\end{bmatrix},$$

前两个未知量为 $\boldsymbol{u}$，最后一个为 v，于是 $\boldsymbol{B}=\left[\begin{smallmatrix}4&1\\1&3\end{smallmatrix}\right]$，$\boldsymbol{C}=(1,0)^{\mathsf{T}}$，$\boldsymbol{D}=\boldsymbol{C}^{\mathsf{T}}$，$\boldsymbol{E}=2$，$\boldsymbol{f}=(6,4)^{\mathsf{T}}$，$g=3$。$\boldsymbol{B}$ 对称正定，用同一个分解求解

两个右端：$\boldsymbol{B}\boldsymbol{z}=\boldsymbol{f}$ 给出 $\boldsymbol{z}=(\frac{14}{11},\frac{10}{11})^{\top}$，$\boldsymbol{B}\boldsymbol{Z}=\boldsymbol{C}$ 给出 $\boldsymbol{Z}=(\frac{3}{11},-\frac{1}{11})^{\top}$；代回可验 $4\cdot\frac{14}{11}+\frac{10}{11}=6$、$\frac{14}{11}+3\cdot\frac{10}{11}=4$。

约化方程的系数与右端为 $S=2-\frac{3}{11}=\frac{19}{11}$、$h=3-\frac{14}{11}=\frac{19}{11}$，解得 $v=1$。恢复得 $\boldsymbol{u}=(\frac{14}{11},\frac{10}{11})^{\top}-(\frac{3}{11},-\frac{1}{11})^{\top}=(1,1)^{\top}$，所以 $\boldsymbol{x}=(1,1,1)^{\top}$，两组原方程的残差均为零。$S>0$ 与 $\boldsymbol{A}$ 对称正定一致。推导中出现的 $\boldsymbol{B}^{-1}$ 在程序里始终是已存因子上的三角求解。

10.4.3 算法分析

正确性 按构造，$(\boldsymbol{u},v)$ 满足第一组方程，而在 $\boldsymbol{u}=\boldsymbol{z}-\boldsymbol{Z}v$ 下第二组方程恰好等价于 $\boldsymbol{S}v=h$；反之，原方程的任何解都满足这两个关系。所以约化方程与原分块方程双向等价，算法给出原方程的解。把消元写成矩阵乘法，还能读出整体可逆性、逆矩阵和正定性。

定理 10.11 Schur 补的行列式、逆与正定性 设 $\boldsymbol{B}$ 可逆，$\boldsymbol{S}=\boldsymbol{E}-\boldsymbol{D}\boldsymbol{B}^{-1}\boldsymbol{C}$。则 $\det\boldsymbol{A}=\det\boldsymbol{B}\det\boldsymbol{S}$，$\boldsymbol{A}$ 可逆当且仅当 $\boldsymbol{S}$ 可逆，此时

$$\boldsymbol{A}^{-1}=\begin{bmatrix}\boldsymbol{B}^{-1}+\boldsymbol{B}^{-1}\boldsymbol{C}\boldsymbol{S}^{-1}\boldsymbol{D}\boldsymbol{B}^{-1} & -\boldsymbol{B}^{-1}\boldsymbol{C}\boldsymbol{S}^{-1}\\ -\boldsymbol{S}^{-1}\boldsymbol{D}\boldsymbol{B}^{-1} & \boldsymbol{S}^{-1}\end{bmatrix}. \tag{10.8}$$

同理，若 $\boldsymbol{E}$ 可逆，则 $\det\boldsymbol{A}=\det\boldsymbol{E}\det(\boldsymbol{B}-\boldsymbol{C}\boldsymbol{E}^{-1}\boldsymbol{D})$。若 $\boldsymbol{A}$ 对称（$\boldsymbol{D}=\boldsymbol{C}^{\top}$）且 $\boldsymbol{B}\succ 0$，则

$$\boldsymbol{A}\succ 0 \iff \boldsymbol{E}-\boldsymbol{C}^{\top}\boldsymbol{B}^{-1}\boldsymbol{C}\succ 0. \tag{10.9}$$

证明 消去左下块再消去右上块，得到

$$\boldsymbol{A}=\begin{bmatrix}\boldsymbol{I} & \boldsymbol{0}\\ \boldsymbol{D}\boldsymbol{B}^{-1} & \boldsymbol{I}\end{bmatrix}\begin{bmatrix}\boldsymbol{B} & \boldsymbol{0}\\ \boldsymbol{0} & \boldsymbol{S}\end{bmatrix}\begin{bmatrix}\boldsymbol{I} & \boldsymbol{B}^{-1}\boldsymbol{C}\\ \boldsymbol{0} & \boldsymbol{I}\end{bmatrix},$$

按分块乘法相乘即可验证。两侧单位块三角因子的行列式为 1，取行列式得 $\det\boldsymbol{A}=\det\boldsymbol{B}\det\boldsymbol{S}$，又 $\det\boldsymbol{B}\neq 0$，故 $\boldsymbol{A}$ 可逆当且仅当 $\boldsymbol{S}$ 可逆。此时三个因子分别求逆：单位块三角因子的逆只需把非对角块变号，中间因子的逆是 $\operatorname{diag}(\boldsymbol{B}^{-1},\boldsymbol{S}^{-1})$，按相反顺序相乘即得式 (10.8)。$\boldsymbol{E}$ 可逆时先消去 $\boldsymbol{v}$，同样的论证给出第二个行列式公式。对称时右侧因子是左侧因子的转置，上式写成 $\boldsymbol{A}=\boldsymbol{G}\operatorname{diag}(\boldsymbol{B},\boldsymbol{S})\boldsymbol{G}^{\top}$，其中 $\boldsymbol{G}$ 可逆；展开二次型即是对 $\boldsymbol{u}$ 配方：

$$\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x}=(\boldsymbol{u}+\boldsymbol{B}^{-1}\boldsymbol{C}\boldsymbol{v})^{\top}\boldsymbol{B}(\boldsymbol{u}+\boldsymbol{B}^{-1}\boldsymbol{C}\boldsymbol{v})+\boldsymbol{v}^{\top}\boldsymbol{S}\boldsymbol{v}.$$

> $\boldsymbol{G}^{\top}$ 可逆，所以 $\boldsymbol{A} \succ 0$ 当且仅当 $\operatorname{diag}(\boldsymbol{B}, \boldsymbol{S}) \succ 0$；已知 $\boldsymbol{B} \succ 0$，这又等价于 $\boldsymbol{S} \succ 0$。 ■

数值敏感度　误差来自三处：用 $\boldsymbol{B}$ 的因子求 $\boldsymbol{Z}$ 与 $\boldsymbol{z}$，形成 $\boldsymbol{S} = \boldsymbol{E} - \boldsymbol{D}\boldsymbol{Z}$ 时的相减，以及约化方程的求解。$\boldsymbol{B}$ 病态时，$\boldsymbol{Z}$ 与 $\boldsymbol{z}$ 的误差会传入 $\boldsymbol{S}$ 与 $\boldsymbol{h}$，相当于块层面的小主元，这时应换一种分组。

计算代价与消元顺序　若 $\boldsymbol{B}$ 稠密，各步合计与对整个 $\boldsymbol{A}$ 作 LU 同为 $(p+q)^3$ 量级，单纯改写成分块形式并不省事；节省须依赖被消块易于求解（例如块对角，各小块可以分别分解）或保留块较小。消元顺序还影响稀疏性：即使 $\boldsymbol{A}$ 稀疏，$\boldsymbol{S} = \boldsymbol{E} - \boldsymbol{D}\boldsymbol{Z}$ 一般比 $\boldsymbol{E}$ 稠密，这是块层面的填充。先消哪一组决定了需要分解的矩阵规模、$\boldsymbol{S}$ 的稠密程度，以及哪一个因子可以在多个右端或多次求解之间复用。

10.5　低秩更新下的求解

实际计算中常常要连续求解一系列只相差少量修改的方程，例如新增或删除一个约束、调整一个参数后重新求解。若每次修改的秩很小，就不必重新分解整个矩阵，而可以复用旧矩阵的分解，只多解一个低阶系统。这一节省依赖两个前提：旧分解已经存在，并且修改的秩远小于矩阵阶数。

10.5.1　主要思想

设新的系数矩阵具有已知结构

$$\boldsymbol{A} = \boldsymbol{A}_0 + \boldsymbol{U}\boldsymbol{C}\boldsymbol{V}^{\top},$$

其中 $\boldsymbol{A}_0 \in \mathbb{R}^{d\times d}$ 非奇异，$\boldsymbol{U}, \boldsymbol{V} \in \mathbb{R}^{d\times k}$，$\boldsymbol{C} \in \mathbb{R}^{k\times k}$，$k \ll d$，且 $\boldsymbol{A}$ 非奇异；要求 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 的精确解。更新表示是输入矩阵的结构信息，$\boldsymbol{A}_0$ 已有的分解只在内部复用。$\boldsymbol{C}$ 可以吸收修改项中的系数；取 $\boldsymbol{C} = \boldsymbol{I}_k$ 就是常见的 $\boldsymbol{A}_0 + \boldsymbol{U}\boldsymbol{V}^{\top}$。

辅助变量　修改项 $\boldsymbol{U}\boldsymbol{C}\boldsymbol{V}^{\top}\boldsymbol{x}$ 只通过 k 维量 $\boldsymbol{C}\boldsymbol{V}^{\top}\boldsymbol{x}$ 影响方程。令 $\boldsymbol{z} = \boldsymbol{C}\boldsymbol{V}^{\top}\boldsymbol{x}$，原方程写成 $\boldsymbol{A}_0\boldsymbol{x} = \boldsymbol{b} - \boldsymbol{U}\boldsymbol{z}$。用 $\boldsymbol{A}_0$ 的因子求解 $\boldsymbol{A}_0\boldsymbol{u} = \boldsymbol{b}$ 与 $\boldsymbol{A}_0\boldsymbol{Z} = \boldsymbol{U}$，就得到

$$\boldsymbol{x} = \boldsymbol{u} - \boldsymbol{Z}\boldsymbol{z}.$$

两边左乘 $\boldsymbol{C}\boldsymbol{V}^{\top}$，由 $\boldsymbol{z}$ 的定义得 $\boldsymbol{z} = \boldsymbol{C}\boldsymbol{V}^{\top}\boldsymbol{u} - \boldsymbol{C}\boldsymbol{V}^{\top}\boldsymbol{Z}\boldsymbol{z}$，移项便是 k 阶方程

$$\boldsymbol{K}\boldsymbol{z} = \boldsymbol{h}, \qquad \boldsymbol{K} = \boldsymbol{I}_k + \boldsymbol{C}\boldsymbol{V}^{\top}\boldsymbol{Z}, \quad \boldsymbol{h} = \boldsymbol{C}\boldsymbol{V}^{\top}\boldsymbol{u}.$$

所以完整的计算只需要旧因子上的 $k+1$ 个右端求解，以及一个 k 阶辅助方程的求解；解出 $\boldsymbol{z}$ 后代回 $\boldsymbol{x}=\boldsymbol{u}-\boldsymbol{Z}\boldsymbol{z}$。

秩一修改　最常见的是秩一修改 $\boldsymbol{A}=\boldsymbol{A}_0+\boldsymbol{p}\boldsymbol{q}^{\top}$，即 $k=1$、$\boldsymbol{U}=\boldsymbol{p}$、$\boldsymbol{V}=\boldsymbol{q}$、$\boldsymbol{C}=1$。这时 $\boldsymbol{Z}$ 是一个向量，记 $\boldsymbol{A}_0\boldsymbol{w}=\boldsymbol{p}$，辅助方程退化为标量除法：

$$z=\frac{\boldsymbol{q}^{\top}\boldsymbol{u}}{1+\boldsymbol{q}^{\top}\boldsymbol{w}},\qquad \boldsymbol{x}=\boldsymbol{u}-z\boldsymbol{w}.$$

分母为零表示更新后的矩阵奇异（定理 10.15）；分母很小则提示结果可能对舍入很敏感，低阶运算并不自动意味着稳定。

10.5.2 算法实现

用旧因子求解　先取得 $\boldsymbol{A}_0$ 的分解。它通常已经存在，可以直接复用；尚无分解时先按 $\boldsymbol{A}_0$ 的结构调用前面的方法求得。下面关于节省计算的比较，以分解已经存在为前提。用这组因子求解 $\boldsymbol{A}_0\boldsymbol{u}=\boldsymbol{b}$，得到未作更新时的解 $\boldsymbol{u}$；再对 $\boldsymbol{U}$ 的 k 列复用同一组因子，求解 $\boldsymbol{A}_0\boldsymbol{Z}=\boldsymbol{U}$，得到 $\boldsymbol{Z}\in\mathbb{R}^{d\times k}$，它记录修改方向经 $\boldsymbol{A}_0^{-1}$ 作用后的结果。

形成小系统　形成 k 阶矩阵 $\boldsymbol{K}=\boldsymbol{I}_k+\boldsymbol{C}\boldsymbol{V}^{\top}\boldsymbol{Z}$ 与 k 维向量 $\boldsymbol{h}=\boldsymbol{C}\boldsymbol{V}^{\top}\boldsymbol{u}$。计算时先算 $\boldsymbol{V}^{\top}\boldsymbol{Z}$ 与 $\boldsymbol{V}^{\top}\boldsymbol{u}$，再左乘 $\boldsymbol{C}$，全程不形成新的 d 阶矩阵。

求解小系统并修正　调用已有的直接法求解 $\boldsymbol{K}\boldsymbol{z}=\boldsymbol{h}$；$\boldsymbol{K}$ 奇异时停止，因为更新后的矩阵也奇异。再计算 $\boldsymbol{x}=\boldsymbol{u}-\boldsymbol{Z}\boldsymbol{z}$，得到新方程的解。每次修正之后都应在更新后的矩阵下重算原残差 $\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}$，而不是只检查辅助方程。

示例 10.12　秩一更新的计算　把二阶贯穿例看成一个易解矩阵加上秩一修改：$\boldsymbol{A}=\left[\begin{smallmatrix}4&1\\1&3\end{smallmatrix}\right]$ 等于 $\boldsymbol{A}_0=\operatorname{diag}(3,2)$ 加上 $\boldsymbol{U}\boldsymbol{C}\boldsymbol{V}^{\top}$，其中 $\boldsymbol{U}=\boldsymbol{V}=(1,1)^{\top}$，$\boldsymbol{C}=1$；右端 $\boldsymbol{b}=(1,2)^{\top}$。$\boldsymbol{A}_0$ 是对角矩阵，用它求解只需逐个相除，得 $\boldsymbol{u}=(\tfrac{1}{3},1)^{\top}$，$\boldsymbol{Z}=(\tfrac{1}{3},\tfrac{1}{2})^{\top}$。

修改的秩为一，小系统只是一个标量方程：$\boldsymbol{K}=1+\tfrac{1}{3}+\tfrac{1}{2}=\tfrac{11}{6}$，$\boldsymbol{h}=\tfrac{1}{3}+1=\tfrac{4}{3}$，于是 $\boldsymbol{z}=\tfrac{4}{3}\cdot\tfrac{6}{11}=\tfrac{8}{11}$。修正后

$$\boldsymbol{x}=\begin{bmatrix}\frac{1}{3}\\1\end{bmatrix}-\frac{8}{11}\begin{bmatrix}\frac{1}{3}\\\frac{1}{2}\end{bmatrix}=\begin{bmatrix}\frac{1}{11}\\\frac{7}{11}\end{bmatrix},$$

与例 10.9的结果一致，全程没有分解 $\boldsymbol{A}$ 本身。

上例的修改是对称的。下例取 $\boldsymbol{U}\neq\boldsymbol{V}$，修改后的矩阵不再对称，但计算步骤不变。

示例 10.13　非对称的秩一更新　取 $\boldsymbol{A}_0 = \operatorname{diag}(2,3)$，$\boldsymbol{U} = (1,1)^{\top}$，$\boldsymbol{V} = (1,0)^{\top}$，$\boldsymbol{C} = 1$，$\boldsymbol{b} = (4,5)^{\top}$，更新后的矩阵为 $\boldsymbol{A} = \left[\begin{smallmatrix} 3 & 0 \\ 1 & 3 \end{smallmatrix}\right]$。旧因子给出 $\boldsymbol{u} = (2, \frac{5}{3})^{\top}$ 与 $\boldsymbol{Z} = (\frac{1}{2}, \frac{1}{3})^{\top}$。小系统为 $\boldsymbol{K} = 1 + \boldsymbol{V}^{\top}\boldsymbol{Z} = \frac{3}{2}$、$\boldsymbol{h} = \boldsymbol{V}^{\top}\boldsymbol{u} = 2$，所以 $z = \frac{4}{3}$，修正得

$$\boldsymbol{x} = \begin{bmatrix} 2 \\ \frac{5}{3} \end{bmatrix} - \frac{4}{3}\begin{bmatrix} \frac{1}{2} \\ \frac{1}{3} \end{bmatrix} = \begin{bmatrix} \frac{4}{3} \\ \frac{11}{9} \end{bmatrix}.$$

用更新后的矩阵重算：$3 \cdot \frac{4}{3} = 4$，$\frac{4}{3} + 3 \cdot \frac{11}{9} = 5$，原残差为零。若连续作多次更新，辅助系统可能逐渐病态，误差也会累积，这时应与重新分解的代价比较，而不无限复用旧因子。

10.5.3 算法分析

正确性　主要思想已经说明原方程的解满足 $\boldsymbol{x} = \boldsymbol{u} - \boldsymbol{Z}\boldsymbol{z}$ 与 $\boldsymbol{K}\boldsymbol{z} = \boldsymbol{h}$。反过来，若 $\boldsymbol{K}\boldsymbol{z} = \boldsymbol{h}$ 且 $\boldsymbol{x} = \boldsymbol{u} - \boldsymbol{Z}\boldsymbol{z}$，则 $\boldsymbol{C}\boldsymbol{V}^{\top}\boldsymbol{x} = \boldsymbol{h} - (\boldsymbol{K} - \boldsymbol{I}_k)\boldsymbol{z} = \boldsymbol{z}$，从而 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{A}_0\boldsymbol{x} + \boldsymbol{U}\boldsymbol{z} = \boldsymbol{b}$。所以小系统与原方程等价。把这一等价关系对任意右端写成矩阵形式，就得到下面的可逆性判据与逆矩阵公式。

定理 10.14　Woodbury 恒等式　设 $\boldsymbol{A}_0 \in \mathbb{R}^{d\times d}$ 可逆，$\boldsymbol{U}, \boldsymbol{V} \in \mathbb{R}^{d\times k}$，$\boldsymbol{C} \in \mathbb{R}^{k\times k}$，记 $\boldsymbol{K} = \boldsymbol{I}_k + \boldsymbol{C}\boldsymbol{V}^{\top}\boldsymbol{A}_0^{-1}\boldsymbol{U}$。则

$$\det(\boldsymbol{A}_0 + \boldsymbol{U}\boldsymbol{C}\boldsymbol{V}^{\top}) = \det \boldsymbol{A}_0 \det \boldsymbol{K},$$

因而 $\boldsymbol{A}_0 + \boldsymbol{U}\boldsymbol{C}\boldsymbol{V}^{\top}$ 可逆当且仅当 $\boldsymbol{K}$ 可逆。若 $\boldsymbol{C}$ 也可逆且 $\boldsymbol{K}$ 可逆，则成立Woodbury 恒等式（Woodbury identity）

$$\begin{aligned} &(\boldsymbol{A}_0 + \boldsymbol{U}\boldsymbol{C}\boldsymbol{V}^{\top})^{-1} \\ &= \boldsymbol{A}_0^{-1} - \boldsymbol{A}_0^{-1}\boldsymbol{U}(\boldsymbol{C}^{-1} + \boldsymbol{V}^{\top}\boldsymbol{A}_0^{-1}\boldsymbol{U})^{-1}\boldsymbol{V}^{\top}\boldsymbol{A}_0^{-1}. \end{aligned} \tag{10.10}$$

证明　记 $\boldsymbol{Z} = \boldsymbol{A}_0^{-1}\boldsymbol{U}$，则 $\boldsymbol{A}_0 + \boldsymbol{U}\boldsymbol{C}\boldsymbol{V}^{\top} = \boldsymbol{A}_0(\boldsymbol{I}_d + \boldsymbol{Z}\boldsymbol{C}\boldsymbol{V}^{\top})$。对分块矩阵 $\left[\begin{smallmatrix} \boldsymbol{I}_d & -\boldsymbol{Z} \\ \boldsymbol{C}\boldsymbol{V}^{\top} & \boldsymbol{I}_k \end{smallmatrix}\right]$ 分别消去两个单位对角块，由定理 10.11的两个行列式公式得 $\det(\boldsymbol{I}_d + \boldsymbol{Z}\boldsymbol{C}\boldsymbol{V}^{\top}) = \det(\boldsymbol{I}_k + \boldsymbol{C}\boldsymbol{V}^{\top}\boldsymbol{Z}) = \det \boldsymbol{K}$，第一个结论成立。$\boldsymbol{C}$ 可逆时 $\boldsymbol{K} = \boldsymbol{C}(\boldsymbol{C}^{-1} + \boldsymbol{V}^{\top}\boldsymbol{A}_0^{-1}\boldsymbol{U})$，括号内的矩阵随 $\boldsymbol{K}$ 可逆。由上面的等价关系，对任意 $\boldsymbol{b}$，新方程的解为 $\boldsymbol{x} = \boldsymbol{u} - \boldsymbol{Z}\boldsymbol{K}^{-1}\boldsymbol{C}\boldsymbol{V}^{\top}\boldsymbol{u}$，其中 $\boldsymbol{u} = \boldsymbol{A}_0^{-1}\boldsymbol{b}$；代入 $\boldsymbol{K}^{-1}\boldsymbol{C} = (\boldsymbol{C}^{-1} + \boldsymbol{V}^{\top}\boldsymbol{A}_0^{-1}\boldsymbol{U})^{-1}$，并因 $\boldsymbol{b}$ 任意而去掉右端，即得式 (10.10)。 ■

判据部分允许 $\boldsymbol{C}$ 奇异，这正是算法只使用 $\boldsymbol{K}$、不使用 $\boldsymbol{C}^{-1}$ 的原因。秩一修改时，定理化为一个只含标量分母的公式。

定理 10.15　Sherman–Morrison 公式　设 $\boldsymbol{A}_0 \in \mathbb{R}^{d\times d}$ 可逆，$\boldsymbol{p},\boldsymbol{q} \in \mathbb{R}^d$。则 $\boldsymbol{A}_0 + \boldsymbol{p}\boldsymbol{q}^{\top}$ 可逆当且仅当 $1 + \boldsymbol{q}^{\top}\boldsymbol{A}_0^{-1}\boldsymbol{p} \neq 0$，此时

$$(\boldsymbol{A}_0 + \boldsymbol{p}\boldsymbol{q}^{\top})^{-1} = \boldsymbol{A}_0^{-1} - \frac{\boldsymbol{A}_0^{-1}\boldsymbol{p}\boldsymbol{q}^{\top}\boldsymbol{A}_0^{-1}}{1 + \boldsymbol{q}^{\top}\boldsymbol{A}_0^{-1}\boldsymbol{p}}.$$

证明　在定理 10.14中取 $k=1$、$\boldsymbol{U}=\boldsymbol{p}$、$\boldsymbol{V}=\boldsymbol{q}$、$\boldsymbol{C}=1$，则 $\boldsymbol{K} = 1 + \boldsymbol{q}^{\top}\boldsymbol{A}_0^{-1}\boldsymbol{p}$ 是标量，$(\boldsymbol{C}^{-1} + \boldsymbol{V}^{\top}\boldsymbol{A}_0^{-1}\boldsymbol{U})^{-1} = 1/\boldsymbol{K}$，代入式 (10.10)即得。 ∎

数值敏感度　代数恒等式并不自动保证数值稳定。$\boldsymbol{K}$ 接近奇异时，小系统的求解会放大误差；$\boldsymbol{A}_0$ 的求解本身敏感时，$\boldsymbol{u}$ 与 $\boldsymbol{Z}$ 的误差即使在 $\boldsymbol{A}$ 良态时也会进入结果；$\boldsymbol{u}$ 与 $\boldsymbol{Z}\boldsymbol{z}$ 大小相近时，相减还会发生相消。

计算代价　已有因子时，$k+1$ 个右端的三角求解约需 $O(kd^2)$ 次运算，形成 $\boldsymbol{V}^{\top}\boldsymbol{Z}$ 约需 $O(k^2 d)$，求解小系统约需 $O(k^3)$，合计 $O(kd^2 + k^2 d + k^3)$；优势来自 k 远小于 d，此时远少于重新分解的 $\tfrac{2}{3}d^3$。连续多次更新时，累计的辅助维数和误差都会增长，到一定程度后重新分解更合算。

10.6 正规方程法

前五节处理的都是方阵的精确解。现在转向超定的最小二乘问题，矩阵不再是方阵，消元也不再直接适用。最直接的办法是先把问题化为一个方阵问题：最小二乘解满足正规方程，而满列秩时正规方程的系数矩阵对称正定，正好可以交给 Cholesky 分解。

10.6.1 主要思想

输入满列秩的 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$（$m \geq d$）和 $\boldsymbol{b} \in \mathbb{R}^m$，求唯一的最小二乘解 $\hat{\boldsymbol{x}}$。

从残差正交到正规方程　记残差 $\boldsymbol{r} = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}$。第 9.2节已经证明，最优拟合值是 $\boldsymbol{b}$ 在列空间上的正交投影，所以最优时残差与 $\boldsymbol{A}$ 的每一列 $\boldsymbol{a}_j$ 正交：$\boldsymbol{a}_j^{\top}(\boldsymbol{b} - \boldsymbol{A}\hat{\boldsymbol{x}}) = 0$，$j = 1,\dots,d$。把这 d 个标量等式堆叠起来，就是正规方程

$$\boldsymbol{A}^{\top}\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{A}^{\top}\boldsymbol{b}$$

（式 (9.5)）。这一推导只用正交投影，不需要多元求导。

满列秩保证正定　记 $\boldsymbol{G}=\boldsymbol{A}^{\top}\boldsymbol{A}$。若 $\boldsymbol{A}$ 满列秩，则对任意 $\boldsymbol{z}\neq\boldsymbol{0}$ 有 $\boldsymbol{A}\boldsymbol{z}\neq\boldsymbol{0}$，于是 $\boldsymbol{z}^{\top}\boldsymbol{G}\boldsymbol{z}=\|\boldsymbol{A}\boldsymbol{z}\|_2^2>0$，$\boldsymbol{G}$ 对称正定。这样 $m\times d$ 的最小二乘问题就变成一个 d 阶正定方程，可以用第 10.2节的 Cholesky 分解 $\boldsymbol{G}=\boldsymbol{L}\boldsymbol{L}^{\top}$ 求出唯一解。秩亏时这一正定论证失效，应改用后面的 QR 或 SVD 分支。

按行累计　把 $\boldsymbol{A}$ 的第 i 行记为 $\boldsymbol{A}_{i,:}$，逐元素展开矩阵乘法可知

$$\boldsymbol{G}=\sum_{i=1}^{m}\boldsymbol{A}_{i,:}^{\top}\boldsymbol{A}_{i,:},\qquad \boldsymbol{A}^{\top}\boldsymbol{b}=\sum_{i=1}^{m}b_i\boldsymbol{A}_{i,:}^{\top}.$$

每条观测只贡献一个 d 阶外积和一个 d 维向量，所以可以每读入一行就把它的贡献累加进去，不必同时保存全部观测行。这是正规方程法在数据量很大时的主要优点。代数上等价并不意味着数值条件相同：$\boldsymbol{G}$ 的条件数是 $\boldsymbol{A}$ 的平方（定理 10.17），这是后面引入 QR 求解的原因。

10.6.2　算法实现

形成 Gram 矩阵　第一步形成 Gram 矩阵 $\boldsymbol{G}=\boldsymbol{A}^{\top}\boldsymbol{A}$ 与右端 $\boldsymbol{c}=\boldsymbol{A}^{\top}\boldsymbol{b}$：先令 $\boldsymbol{G}=\boldsymbol{0}$、$\boldsymbol{c}=\boldsymbol{0}$，再对 $i=1,\dots,m$ 依次累加

$$\boldsymbol{G}\leftarrow\boldsymbol{G}+\boldsymbol{A}_{i,:}^{\top}\boldsymbol{A}_{i,:},\qquad \boldsymbol{c}\leftarrow\boldsymbol{c}+b_i\boldsymbol{A}_{i,:}^{\top}.$$

$\boldsymbol{G}$ 对称，只需累加下三角部分。

$\boldsymbol{L}\boldsymbol{L}^{\top}$ 分解　然后用第 10.2节的逐列过程计算 $\boldsymbol{G}=\boldsymbol{L}\boldsymbol{L}^{\top}$。满列秩保证了这一步的正定前提；若分解中出现非正的开方量，说明 $\boldsymbol{A}$ 秩亏或条件很差，应转入 QR 或 SVD 求解。

前代与回代　有了因子，先用第 10.1节的前代求解 $\boldsymbol{L}\boldsymbol{y}=\boldsymbol{c}$，再用回代求解 $\boldsymbol{L}^{\top}\hat{\boldsymbol{x}}=\boldsymbol{y}$，得到最小二乘解 $\hat{\boldsymbol{x}}$。两次三角求解的次序来自 $\boldsymbol{L}(\boldsymbol{L}^{\top}\hat{\boldsymbol{x}})=\boldsymbol{c}$，与用 Cholesky 分解解正定方程的步骤相同。

示例 10.16　直线拟合的正规方程法　沿用示例 9.4的直线拟合，$\boldsymbol{A}=\left[\begin{smallmatrix}1&0\\1&1\\1&2\end{smallmatrix}\right]$，$\boldsymbol{b}=(1,2,2)^{\top}$，按正规方程法的次序计算：先逐行累计 $\boldsymbol{G}$ 与 $\boldsymbol{c}$，再分解 $\boldsymbol{G}$ 并作两次三角求解。三行依次给出 $\boldsymbol{G}$ 的增量

$$\begin{bmatrix}1&0\\0&0\end{bmatrix},\quad\begin{bmatrix}1&1\\1&1\end{bmatrix},\quad\begin{bmatrix}1&2\\2&4\end{bmatrix},$$

以及 $\boldsymbol{c}$ 的增量 $(1,0)^{\top}$、$(2,2)^{\top}$、$(2,4)^{\top}$，因此 $\boldsymbol{G}=\left[\begin{smallmatrix}3&3\\3&5\end{smallmatrix}\right]$，$\boldsymbol{c}=(5,6)^{\top}$。

对 $\boldsymbol{G}$ 作 Cholesky 分解，得 $l_{1,1}=\sqrt{3}$、$l_{2,1}=3/\sqrt{3}=\sqrt{3}$、$l_{2,2}=\sqrt{5-3}=\sqrt{2}$，即 $\boldsymbol{L}=\begin{bmatrix}\sqrt{3} & 0\\ \sqrt{3} & \sqrt{2}\end{bmatrix}$。前代得 $y_1=5/\sqrt{3}$，$y_2=(6-\sqrt{3}\cdot 5/\sqrt{3})/\sqrt{2}=1/\sqrt{2}$；回代得 $\hat{x}_2=1/2$，$\hat{x}_1=(5/\sqrt{3}-\sqrt{3}/2)/\sqrt{3}=5/3-1/2=7/6$。

最后用原始数据重算残差：$\boldsymbol{r}=\boldsymbol{b}-\boldsymbol{A}\hat{\boldsymbol{x}}=(-\frac{1}{6},\frac{1}{3},-\frac{1}{6})^{\top}$，它与两列都正交，$\boldsymbol{A}^{\top}\boldsymbol{r}=\boldsymbol{0}$，且 $\|\boldsymbol{r}\|_2^2=\frac{1}{6}$。原残差不为零，是因为三个点本来就不共线，方程不相容；最小二乘完成的标志是 $\boldsymbol{A}^{\top}\boldsymbol{r}=\boldsymbol{0}$，而不是 $\boldsymbol{r}=\boldsymbol{0}$。若累计后的 Cholesky 分解失败，或结果对舍入很敏感，也不能只凭正规方程这个小系统的残差小就宣布结果可靠。

10.6.3 算法分析

正确性 两次三角求解给出 $\boldsymbol{L}\boldsymbol{L}^{\top}\hat{\boldsymbol{x}}=\boldsymbol{c}$，即 $\boldsymbol{A}^{\top}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\top}\boldsymbol{b}$，所以 $\hat{\boldsymbol{x}}$ 满足正规方程，由定理 9.3是唯一的最小二乘解。

数值敏感度 这条路线的代价在精度。对满列秩矩阵定义 $\kappa_2(\boldsymbol{A})=\sigma_{\max}(\boldsymbol{A})/\sigma_{\min}(\boldsymbol{A})$，方阵时它与第 7.1.3节的定义一致。

定理 10.17 正规方程使条件数平方 设 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$ 满列秩，则 $\kappa_2(\boldsymbol{A}^{\top}\boldsymbol{A})=\kappa_2(\boldsymbol{A})^2$。

证明 由第 5章的奇异值分解 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$，得

$$\boldsymbol{A}^{\top}\boldsymbol{A}=\boldsymbol{V}\,\mathrm{diag}(\sigma_1^2,\dots,\sigma_d^2)\boldsymbol{V}^{\top}.$$

满列秩时 $\sigma_d>0$，这是对称正定矩阵的谱分解，其最大、最小特征值即最大、最小奇异值，分别为 σ_1^2 与 σ_d^2，故 $\kappa_2(\boldsymbol{A}^{\top}\boldsymbol{A})=\sigma_1^2/\sigma_d^2=\kappa_2(\boldsymbol{A})^2$。 ■

$\boldsymbol{A}$ 压缩得很厉害的方向在 $\boldsymbol{G}$ 中被压缩两次，形成 $\boldsymbol{G}$ 时累计内积的舍入就可能抹掉这些方向上的信息。因此正规方程法适合条件较好的满列秩问题；误差界怎样带上 $\kappa_2(\boldsymbol{A})^2$，见第 14.1.3节。

计算代价与适用范围 形成 Gram 矩阵可能增加填充：$\boldsymbol{A}$ 只要有一行全是非零元，这一行的外积就使 $\boldsymbol{G}$ 成为稠密矩阵。稠密情形下形成 $\boldsymbol{G}$ 约需 md^2 次运算，分解约需 $d^3/3$ 次，总工作为 $O(md^2+d^3)$。秩亏时正规方程仍刻画全部最小二乘解，但 $\boldsymbol{G}$ 只是半正定的，Cholesky 分解会遇到零主元，本算法的前提不再成立；这时的选解由第 10.8节的 SVD 路线完成。

10.7　QR 求解

正规方程法的精度损失来自形成 $\boldsymbol{A}^{\top}\boldsymbol{A}$。QR 求解不形成它，而是直接对 $\boldsymbol{A}$ 作正交三角化。本节先利用 QR 因子写清最小二乘与满行秩最小范数解的共同求解过程，再分别说明修正 Gram–Schmidt 正交化、Householder 反射与 Givens 旋转怎样计算这些因子。

10.7.1　主要思想

输入满列秩的 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$（$m\ge d$）和 $\boldsymbol{b}\in\mathbb{R}^{m}$，求唯一的最小二乘解 $\hat{\boldsymbol{x}}$。正交变换保持欧氏长度，用它同时变换 $\boldsymbol{A}$ 和 $\boldsymbol{b}$ 不会改变残差的长度。因此可以找一个正交矩阵把 $\boldsymbol{A}$ 化为上三角形，最小二乘问题就变成一个三角方程，全程不必形成 $\boldsymbol{A}^{\top}\boldsymbol{A}$。

残差的分解　第 3章的薄 QR 分解（式 (3.16)）给出 $\boldsymbol{A}=\boldsymbol{Q}_1\boldsymbol{R}$，其中 $\boldsymbol{Q}_1\in\mathbb{R}^{m\times d}$ 的列标准正交，$\boldsymbol{R}$ 为 d 阶上三角矩阵；满列秩时 $\boldsymbol{R}$ 可逆。把 $\boldsymbol{Q}_1$ 的列补成 $\mathbb{R}^{m}$ 的标准正交基，新增的列排成 $\boldsymbol{Q}_2$，得到完整的分解

$$\boldsymbol{A}=\boldsymbol{Q}\begin{bmatrix}\boldsymbol{R}\\ \boldsymbol{0}\end{bmatrix},\qquad \boldsymbol{Q}=[\boldsymbol{Q}_1\ \boldsymbol{Q}_2].$$

把右端也变换为 $\boldsymbol{Q}^{\top}\boldsymbol{b}=(\boldsymbol{c}_1^{\top},\boldsymbol{c}_2^{\top})^{\top}$，$\boldsymbol{c}_1=\boldsymbol{Q}_1^{\top}\boldsymbol{b}$ 含前 d 个分量。由 $\boldsymbol{Q}^{\top}$ 保持长度，对任意 $\boldsymbol{x}$ 有

$$\begin{aligned}\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|_2^2&=\|\boldsymbol{Q}^{\top}(\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b})\|_2^2\\&=\|\boldsymbol{R}\boldsymbol{x}-\boldsymbol{c}_1\|_2^2+\|\boldsymbol{c}_2\|_2^2.\end{aligned}\tag{10.11}$$

第二项与 $\boldsymbol{x}$ 无关，是任何 $\boldsymbol{x}$ 都无法拟合的部分；第一项可以通过求解 $\boldsymbol{R}\boldsymbol{x}=\boldsymbol{c}_1$ 消为零。

回代与最小残差　$\boldsymbol{R}\boldsymbol{x}=\boldsymbol{c}_1$ 是上三角方程，按式 (10.3)逆序展开，$\hat{x}_i=\big((\boldsymbol{c}_1)_i-\sum_{j>i}r_{i,j}\hat{x}_j\big)/r_{i,i}$。最小残差范数为 $\|\boldsymbol{c}_2\|_2$。使用薄分解时不必补出 $\boldsymbol{Q}_2$：不可拟合部分就是 $\boldsymbol{b}-\boldsymbol{Q}_1\boldsymbol{Q}_1^{\top}\boldsymbol{b}$，即 $\boldsymbol{b}$ 减去它在列空间上的正交投影（第 3.5.4节）。

满行秩的最小范数解　同一种分解也能处理欠定方程。设 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$ 满行秩，$m<d$，求解目标改为第 9.3节的最小范数精确解 $\boldsymbol{x}_\star$。这时对 $\boldsymbol{A}^{\top}$ 而不是 $\boldsymbol{A}$ 作薄 QR 分解 $\boldsymbol{A}^{\top}=\boldsymbol{Q}\boldsymbol{R}$，其中 $\boldsymbol{Q}\in\mathbb{R}^{d\times m}$ 的列标准正交，$\boldsymbol{R}$ 为 m 阶可逆上三角矩阵，于是 $\boldsymbol{A}=\boldsymbol{R}^{\top}\boldsymbol{Q}^{\top}$。任一 $\boldsymbol{x}$ 可唯一写成 $\boldsymbol{x}=\boldsymbol{Q}\boldsymbol{y}+\boldsymbol{w}$，其中 $\boldsymbol{Q}^{\top}\boldsymbol{w}=\boldsymbol{0}$。由 $\boldsymbol{A}\boldsymbol{w}=\boldsymbol{R}^{\top}\boldsymbol{Q}^{\top}\boldsymbol{w}=\boldsymbol{0}$，方程化为 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{R}^{\top}\boldsymbol{y}=\boldsymbol{b}$，只约束坐标 $\boldsymbol{y}$；而勾股关系给出 $\|\boldsymbol{x}\|_2^2=\|\boldsymbol{y}\|_2^2+\|\boldsymbol{w}\|_2^2$。所以先前代求解 $\boldsymbol{R}^{\top}\boldsymbol{y}=\boldsymbol{b}$，再令

$\boldsymbol{w} = \mathbf{0}$，输出 $\boldsymbol{x}_\star = \boldsymbol{Q}\boldsymbol{y}$。对转置作分解，是因为最小范数解位于 $\mathrm{range}(\boldsymbol{A}^\top)$ 中，需要的是这个子空间的标准正交基。

只需应用正交因子 两个分支都只用到 $\boldsymbol{Q}^\top$ 或 $\boldsymbol{Q}$ 对向量的作用，并不要求显式存出完整的 $\boldsymbol{Q}$。后面三个小节提供三种计算方式：修正 Gram–Schmidt 直接算出 $\boldsymbol{Q}_1$ 的各列，Householder 方法保存一串反射向量，Givens 方法保存一串旋转参数。它们都服务于上面同一个求解逻辑。

10.7.2 算法实现

QR 分解 第一步计算 QR 分解，或保存相应的正交变换记录；具体做法见后面三个小节。

变换右端 然后对右端施加相同的正交变换，得到回代需要的 $\boldsymbol{c}_1 = \boldsymbol{Q}_1^\top \boldsymbol{b}$。使用反射或旋转时，把它们依次作用于 $\boldsymbol{b}$，取结果的前 d 个分量，其余分量的长度就是最小残差范数；修正 Gram–Schmidt 中 $\boldsymbol{c}_1$ 的具体计算顺序在第 10.7.4节说明。

求解 $\boldsymbol{R}\hat{\boldsymbol{x}} = \boldsymbol{c}_1$ 用回代求解 $\boldsymbol{R}\hat{\boldsymbol{x}} = \boldsymbol{c}_1$，输出最小二乘解 $\hat{\boldsymbol{x}}$，并以原始数据核验 $\boldsymbol{A}^\top(\boldsymbol{b} - \boldsymbol{A}\hat{\boldsymbol{x}}) = \mathbf{0}$。

欠定情形：转置 QR 满行秩输入则分解 $\boldsymbol{A}^\top = \boldsymbol{Q}\boldsymbol{R}$，前代求解 $\boldsymbol{R}^\top \boldsymbol{y} = \boldsymbol{b}$，计算 $\boldsymbol{x}_\star = \boldsymbol{Q}\boldsymbol{y}$，并检查 $\boldsymbol{A}\boldsymbol{x}_\star = \boldsymbol{b}$ 及 $\boldsymbol{x}_\star \in \mathrm{range}(\boldsymbol{A}^\top)$。先解 $\boldsymbol{A}\boldsymbol{A}^\top \boldsymbol{z} = \boldsymbol{b}$ 再取 $\boldsymbol{A}^\top \boldsymbol{z}$ 也得到同一个解，但要先形成 Gram 矩阵 $\boldsymbol{A}\boldsymbol{A}^\top$，转置 QR 避免了这一步。

示例 10.18　由 QR 因子求最小二乘解 取 $\boldsymbol{A} = \left[\begin{smallmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{smallmatrix}\right]$，$\boldsymbol{b} = (1,1,2)^\top$。它的薄 QR 因子可取

$$\boldsymbol{q}_1 = \tfrac{1}{\sqrt{2}}(1,1,0)^\top, \quad \boldsymbol{q}_2 = \tfrac{1}{\sqrt{6}}(-1,1,2)^\top, \quad \boldsymbol{R} = \begin{bmatrix} \sqrt{2} & 1/\sqrt{2} \\ 0 & \sqrt{3/2} \end{bmatrix},$$

这里先把因子当作已知，只看怎样用它求解；因子的计算过程在示例 10.21中给出。变换右端得 $\boldsymbol{c}_1 = (\boldsymbol{q}_1^\top \boldsymbol{b}, \boldsymbol{q}_2^\top \boldsymbol{b})^\top = (\sqrt{2}, 4/\sqrt{6})^\top$。回代先得 $\hat{x}_2 = (4/\sqrt{6})/\sqrt{3/2} = 4/3$，再得 $\hat{x}_1 = \big(\sqrt{2} - \tfrac{1}{\sqrt{2}} \cdot \tfrac{4}{3}\big)/\sqrt{2} = 1/3$。

用原始数据核验，残差 $\boldsymbol{r} = \boldsymbol{b} - \boldsymbol{A}\hat{\boldsymbol{x}} = (\tfrac{2}{3}, -\tfrac{2}{3}, \tfrac{2}{3})^\top$ 满足 $\boldsymbol{A}^\top \boldsymbol{r} = \mathbf{0}$，所以 $\hat{\boldsymbol{x}}$ 确是最小二乘解。若把 $\boldsymbol{Q}_1$ 补齐为正交方阵，第三个标准正交向量为 $\boldsymbol{q}_3 = \tfrac{1}{\sqrt{3}}(1,-1,1)^\top$，由它读出的 $\boldsymbol{c}_2 = \boldsymbol{q}_3^\top \boldsymbol{b} = 2/\sqrt{3}$ 正是 $\|\boldsymbol{r}\|_2$：变换后的右端同时给出了解和最小残差。

示例 10.19　转置 QR 给出最小范数解　再看欠定情形。取 $\boldsymbol{A} = \left[\begin{smallmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{smallmatrix}\right]$，$\boldsymbol{b} = (1,2)^{\mathsf{T}}$，方程有无穷多解，要用转置 QR 找出其中范数最小的一个。$\boldsymbol{A}^{\mathsf{T}}$ 的两列为 $(1,0,1)^{\mathsf{T}}$ 与 $(0,1,1)^{\mathsf{T}}$，按同样的正交化得 $\boldsymbol{q}_1 = \frac{1}{\sqrt{2}}(1,0,1)^{\mathsf{T}}$、$\boldsymbol{q}_2 = \frac{1}{\sqrt{6}}(-1,2,1)^{\mathsf{T}}$，三角因子与上例的 $\boldsymbol{R}$ 相同。前代求解 $\boldsymbol{R}^{\mathsf{T}}\boldsymbol{y} = \boldsymbol{b}$：$\sqrt{2}\,y_1 = 1$ 给出 $y_1 = 1/\sqrt{2}$，$\frac{1}{\sqrt{2}}y_1 + \sqrt{3/2}\,y_2 = 2$ 给出 $y_2 = \sqrt{3/2}$。重建得

$$\boldsymbol{x}_\star = y_1\boldsymbol{q}_1 + y_2\boldsymbol{q}_2 = \tfrac{1}{2}(1,0,1)^{\mathsf{T}} + \tfrac{1}{2}(-1,2,1)^{\mathsf{T}} = (0,1,1)^{\mathsf{T}}.$$

可以直接确认它的范数最小：本例全部解为 $(1-t, 2-t, t)^{\mathsf{T}}$，$t \in \mathbb{R}$，其范数平方为 $(1-t)^2 + (2-t)^2 + t^2 = 3(t-1)^2 + 2$，在 $t = 1$ 时最小，对应的正是 $\boldsymbol{x}_\star$。若相应的三角因子出现零对角元，说明 $\boldsymbol{A}$ 秩亏，应转入 SVD 求解，不能在零对角处直接代入。

10.7.3　算法分析

正确性　两个分支的正确性合写成下面的定理。

定理 10.20　QR 给出最小二乘解与最小范数解　设 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$，$\boldsymbol{b} \in \mathbb{R}^m$。

1. 设 $\boldsymbol{A}$ 满列秩，$\boldsymbol{A} = \boldsymbol{Q}\left[\begin{smallmatrix} \boldsymbol{R} \\ \boldsymbol{0} \end{smallmatrix}\right]$，$\boldsymbol{Q}^{\mathsf{T}}\boldsymbol{b} = \left[\begin{smallmatrix} \boldsymbol{c}_1 \\ \boldsymbol{c}_2 \end{smallmatrix}\right]$。则 $\hat{\boldsymbol{x}} = \boldsymbol{R}^{-1}\boldsymbol{c}_1$ 是唯一的最小二乘解，最小残差范数为 $\|\boldsymbol{c}_2\|_2$。
2. 设 $\boldsymbol{A}$ 满行秩，$\boldsymbol{A}^{\mathsf{T}} = \boldsymbol{Q}\boldsymbol{R}$ 为薄 QR 分解，$\boldsymbol{R}^{\mathsf{T}}\boldsymbol{y} = \boldsymbol{b}$。则 $\boldsymbol{x}_\star = \boldsymbol{Q}\boldsymbol{y}$ 是 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 唯一的最小范数解。

证明　(1) 由式 (10.11)，第二项与 $\boldsymbol{x}$ 无关；$\boldsymbol{R}$ 可逆，第一项当且仅当 $\boldsymbol{x} = \boldsymbol{R}^{-1}\boldsymbol{c}_1$ 时为零。

(2) $\boldsymbol{A}\boldsymbol{x}_\star = \boldsymbol{R}^{\mathsf{T}}\boldsymbol{Q}^{\mathsf{T}}\boldsymbol{Q}\boldsymbol{y} = \boldsymbol{R}^{\mathsf{T}}\boldsymbol{y} = \boldsymbol{b}$，并且 $\boldsymbol{x}_\star \in \operatorname{range}(\boldsymbol{Q}) = \operatorname{range}(\boldsymbol{A}^{\mathsf{T}}) = (\ker \boldsymbol{A})^{\perp}$。任何其他解都与 $\boldsymbol{x}_\star$ 相差 $\ker \boldsymbol{A}$ 中的非零向量，由勾股关系范数更大。 ■

数值敏感度　数值上要区分两个来源：最小二乘问题本身对数据的敏感度由问题决定（第 14.1.3节），计算 QR 因子时引入多少误差则取决于所用的正交化过程。三种实现在因子构造的工作量、数值正交性和残差核验方式上并不相同，下面分别说明。

秩亏情形　秩亏时 $\boldsymbol{R}$ 出现零对角元，不能照搬可逆 $\boldsymbol{R}$ 的回代，最小范数最小二乘解按第 10.8节用 SVD 求解。带列主元的 QR 能把线性无关的主元列

排到前面，但只取主元变量回代、把其余原坐标置零，一般得到的是基本解，不能据此认定它是最小范数解。所以一般秩的情形本章统一使用 SVD 路线。

10.7.4 修正 Gram–Schmidt 正交化

主要思想 修正 Gram–Schmidt（modified Gram–Schmidt）处理满列秩的 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$（$m \ge d$）。它把“减去已经解释的分量”直接落实为对剩余列的更新：每得到一个新的标准正交方向，就立刻从所有尚未处理的列中扣除这一方向上的分量。与第 3章的 Gram–Schmidt 正交化相比，它只差一处：每次投影都作用于已经扣除了前面分量的当前剩余向量，而不是都用原始列计算内积。

具体地，记 $\boldsymbol{v}_k$ 为第 k 列的当前剩余向量，开始时 $\boldsymbol{v}_k = \boldsymbol{a}_k$。设前 $j-1$ 个方向 $\boldsymbol{q}_1, \dots, \boldsymbol{q}_{j-1}$ 已经建立，并且每个剩余向量都已与它们正交。第 j 步取 $r_{j,j} = \|\boldsymbol{v}_j\|_2$、$\boldsymbol{q}_j = \boldsymbol{v}_j / r_{j,j}$；再对每个 $k > j$ 计算投影系数 $r_{j,k} = \boldsymbol{q}_j^{\top}\boldsymbol{v}_k$，并更新

$$\boldsymbol{v}_k \leftarrow \boldsymbol{v}_k - r_{j,k}\boldsymbol{q}_j.$$

更新后的 $\boldsymbol{v}_k$ 与 $\boldsymbol{q}_j$ 正交，且仍与 $\boldsymbol{q}_1, \dots, \boldsymbol{q}_{j-1}$ 正交，因为扣除的是 $\boldsymbol{q}_j$ 方向上的分量。整个过程维持关系

$$\boldsymbol{a}_k = \sum_{i \le j} r_{i,k}\boldsymbol{q}_i + \boldsymbol{v}_k \qquad (k > j),$$

即原始列始终等于已提取的分量加上当前剩余向量。全部列处理完毕时剩余部分已经归入各 $\boldsymbol{q}_k$，得到 $\boldsymbol{A} = \boldsymbol{Q}_1\boldsymbol{R}$，$\boldsymbol{Q}_1 = [\boldsymbol{q}_1, \dots, \boldsymbol{q}_d]$。若某个 $r_{j,j} = 0$，说明第 j 列落在前面各列的张成中，原来的满列秩分支不再适用。

算法实现与算例 初始化 $\boldsymbol{V} = \boldsymbol{A}$、$\boldsymbol{R} = \boldsymbol{0}$，按 $j = 1, \dots, d$ 依次归一化当前列，再用新方向依次更新右侧各列。按列组织时也可以对第 j 列依次扣除 $\boldsymbol{q}_1, \dots, \boldsymbol{q}_{j-1}$ 方向的分量，每次内积都用刚更新过的剩余向量；它对每一列执行的运算与上面完全相同，只是循环次序不同。满列秩保证精确算术下 $r_{j,j} > 0$。有限精度下若发现某列扣除后明显变短，可以对它再正交化一遍，并把第二遍得到的投影系数加到已累计的 $r_{i,j}$ 上，使 $\boldsymbol{A} = \boldsymbol{Q}_1\boldsymbol{R}$ 仍然成立。

右端当作额外的一列处理：令 $\boldsymbol{s} = \boldsymbol{b}$，按 $i = 1, \dots, d$ 依次计算 $c_i = \boldsymbol{q}_i^{\top}\boldsymbol{s}$ 与 $\boldsymbol{s} \leftarrow \boldsymbol{s} - c_i\boldsymbol{q}_i$，得到 $\boldsymbol{c}_1 = (c_1, \dots, c_d)^{\top}$。这一顺序与前面的逐次投影一致；有限精度下 $\boldsymbol{Q}_1$ 的列不完全正交，不宜把它直接换成另算 $\boldsymbol{Q}_1^{\top}\boldsymbol{b}$。最后用回代求解 $\boldsymbol{R}\hat{\boldsymbol{x}} = \boldsymbol{c}_1$，输出 $\hat{\boldsymbol{x}}$。$\boldsymbol{Q}_1$、$\boldsymbol{R}$ 和剩余向量都只是内部状态。

示例 10.21　修正 Gram–Schmidt 的逐步计算　现在补上示例 10.18所用因子的计算，仍取 $\boldsymbol{A}=\left[\begin{smallmatrix}1&0\\1&1\\0&1\end{smallmatrix}\right]$ 与 $\boldsymbol{b}=(1,1,2)^{\top}$。第一步，$r_{1,1}=\|\boldsymbol{a}_1\|_2=\sqrt{2}$，$\boldsymbol{q}_1=\frac{1}{\sqrt{2}}(1,1,0)^{\top}$；投影系数 $r_{1,2}=\boldsymbol{q}_1^{\top}\boldsymbol{a}_2=1/\sqrt{2}$，更新第二列为 $\boldsymbol{v}_2=(0,1,1)^{\top}-\frac{1}{2}(1,1,0)^{\top}=(-\frac{1}{2},\frac{1}{2},1)^{\top}$。第二步，$r_{2,2}=\|\boldsymbol{v}_2\|_2=\sqrt{3/2}$，$\boldsymbol{q}_2=\boldsymbol{v}_2/r_{2,2}=\frac{1}{\sqrt{6}}(-1,1,2)^{\top}$。这就是示例 10.18使用的因子。

右端当作额外的一列，按同样的次序处理：$c_1=\boldsymbol{q}_1^{\top}\boldsymbol{b}=\sqrt{2}$，$\boldsymbol{s}=\boldsymbol{b}-\sqrt{2}\,\boldsymbol{q}_1=(0,0,2)^{\top}$；$c_2=\boldsymbol{q}_2^{\top}\boldsymbol{s}=4/\sqrt{6}$。回代得 $\hat{\boldsymbol{x}}=(\frac{1}{3},\frac{4}{3})^{\top}$，与示例 10.18相同。三项性质要分别核验：$\boldsymbol{q}_1^{\top}\boldsymbol{q}_2=(-1+1+0)/\sqrt{12}=0$ 且两列长度为 1，即 $\boldsymbol{Q}_1^{\top}\boldsymbol{Q}_1=\boldsymbol{I}$；$\boldsymbol{Q}_1\boldsymbol{R}$ 的第二列为 $\frac{1}{\sqrt{2}}\boldsymbol{q}_1+\sqrt{3/2}\,\boldsymbol{q}_2=(0,1,1)^{\top}$，即 $\boldsymbol{Q}_1\boldsymbol{R}=\boldsymbol{A}$；以及 $\boldsymbol{A}^{\top}(\boldsymbol{b}-\boldsymbol{A}\hat{\boldsymbol{x}})=\boldsymbol{0}$。

算法分析　精确算术中各 $\boldsymbol{q}_i$ 两两正交，所以对剩余向量和对原始列计算的内积相同：$\boldsymbol{q}_i^{\top}(\boldsymbol{a}_j-\sum_{k<i}r_{k,j}\boldsymbol{q}_k)=\boldsymbol{q}_i^{\top}\boldsymbol{a}_j$。修正形式因而给出与原来相同的 QR 分解，由定理 10.20得到最小二乘解。

有限精度下，近相关的列扣除旧方向后剩余向量很短，其中舍入误差的相对影响被放大，算出的 $\boldsymbol{q}_j$ 会偏离正交，这就是再正交化要处理的情形。检查结果时用 $\|\boldsymbol{Q}_1^{\top}\boldsymbol{Q}_1-\boldsymbol{I}\|$ 衡量正交性，用 $\|\boldsymbol{A}-\boldsymbol{Q}_1\boldsymbol{R}\|$ 衡量重构质量，二者要分开看：后者小并不保证前者小。正交性损失的程度与 $\boldsymbol{A}$ 的条件数有关，具体说明见第 14.1.2节。主要工作约为 $2md^2$ 次运算。

10.7.5　Householder 反射

主要思想　Householder 方法逐列用正交反射消去对角元下方的元素。核心问题是：给定一个列段 $\boldsymbol{y}\neq\boldsymbol{0}$，怎样构造正交矩阵把它映到第一个坐标轴上。Householder 反射（Householder reflection）$\boldsymbol{H}=\boldsymbol{I}-2\boldsymbol{v}\boldsymbol{v}^{\top}/(\boldsymbol{v}^{\top}\boldsymbol{v})$ 把 $\boldsymbol{v}$ 方向的分量变号，保持与 $\boldsymbol{v}$ 正交的分量不变，是关于以 $\boldsymbol{v}$ 为法向的超平面的镜面反射。它对称且正交，所以只需选好 $\boldsymbol{v}$，如图 10.4所示。

希望 $\boldsymbol{H}\boldsymbol{y}=\alpha\boldsymbol{e}_1$。正交变换保持长度，所以必须 $\alpha^2=\boldsymbol{y}^{\top}\boldsymbol{y}$，即 $\alpha=\pm\|\boldsymbol{y}\|_2$。反射把 $\boldsymbol{y}$ 变成 $\boldsymbol{y}-\boldsymbol{v}\cdot 2(\boldsymbol{v}^{\top}\boldsymbol{y})/(\boldsymbol{v}^{\top}\boldsymbol{v})$，结果要等于 $\alpha\boldsymbol{e}_1$，自然的选择是 $\boldsymbol{v}=\boldsymbol{y}-\alpha\boldsymbol{e}_1$。验证这一选择：

$$\boldsymbol{v}^{\top}\boldsymbol{v}=\boldsymbol{y}^{\top}\boldsymbol{y}-2\alpha y_1+\alpha^2=2(\boldsymbol{y}^{\top}\boldsymbol{y}-\alpha y_1),\qquad \boldsymbol{v}^{\top}\boldsymbol{y}=\boldsymbol{y}^{\top}\boldsymbol{y}-\alpha y_1,$$

所以 $2(\boldsymbol{v}^{\top}\boldsymbol{y})/(\boldsymbol{v}^{\top}\boldsymbol{v})=1$，$\boldsymbol{H}\boldsymbol{y}=\boldsymbol{y}-\boldsymbol{v}=\alpha\boldsymbol{e}_1$。

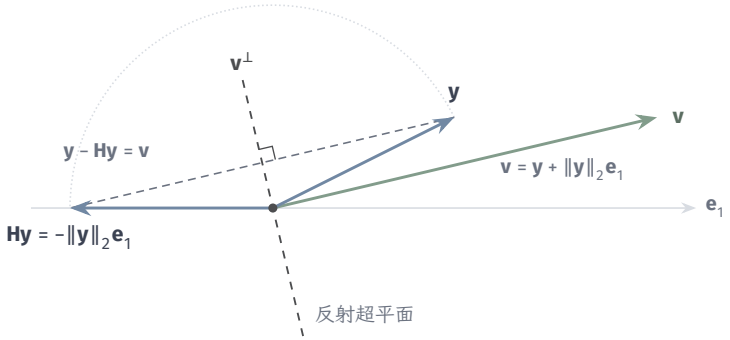


图 10.4　Householder 反射的几何。取 $\boldsymbol{y}=(2,1)^{\top}$，按式 (10.12)令 $\boldsymbol{v}=\boldsymbol{y}+\sqrt{5}\,\boldsymbol{e}_1$。反射超平面 $\boldsymbol{v}^{\perp}$ 是 $\boldsymbol{y}$ 与 $\boldsymbol{H}\boldsymbol{y}=-\sqrt{5}\,\boldsymbol{e}_1$ 连线的垂直平分线，两者之差恰为 $\boldsymbol{v}$；点线圆弧表示反射保持长度。解析式构造。

符号的选择影响数值精度。$\boldsymbol{v}$ 的首分量是 $y_1-\alpha$；若 α 与 y_1 同号且 $\boldsymbol{y}$ 接近 $\boldsymbol{e}_1$ 方向，这是两个相近数相减，会严重相消。因此取 $\alpha=-s\|\boldsymbol{y}\|_2$，其中 $y_1\ge 0$ 时 $s=1$、$y_1<0$ 时 $s=-1$，即

$$\boldsymbol{v}=\boldsymbol{y}+s\|\boldsymbol{y}\|_2\boldsymbol{e}_1,\qquad \boldsymbol{H}=\boldsymbol{I}-\frac{2\boldsymbol{v}\boldsymbol{v}^{\top}}{\boldsymbol{v}^{\top}\boldsymbol{v}},\tag{10.12}$$

这样 $v_1=y_1+s\|\boldsymbol{y}\|_2$ 是两个同号数相加。作用于其他向量时不形成稠密的 $\boldsymbol{H}$：令 $\tau=2/(\boldsymbol{v}^{\top}\boldsymbol{v})$，对任意向量或矩阵 $\boldsymbol{Z}$ 都有 $\boldsymbol{H}\boldsymbol{Z}=\boldsymbol{Z}-\boldsymbol{v}\big(\tau\,\boldsymbol{v}^{\top}\boldsymbol{Z}\big)$，右端也用同一公式更新。

算法实现与算例　对满列秩的 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$（$m\ge d$），先令工作矩阵 $\boldsymbol{F}=\boldsymbol{A}$、工作右端 $\boldsymbol{c}=\boldsymbol{b}$，保持原列顺序，按 $k=1,\dots,d$ 重复下面两步。

第一步构造反射向量。取当前列段 $\boldsymbol{y}=\boldsymbol{F}_{k:m,k}$，按式 (10.12)构造 $\boldsymbol{v}$ 与 τ，保存这一反射记录。由下面的引理，$\boldsymbol{H}\boldsymbol{y}=-s\|\boldsymbol{y}\|_2\boldsymbol{e}_1$，该列下方的元素被消去。$\boldsymbol{y}=\boldsymbol{0}$ 时本步取恒等变换，并记录这一列没有提供新的方向（这意味着秩亏）；对角线下方已经全为零时，也可以取恒等变换，保持该列不变。

第二步作用于剩余子块。把同一个 $\boldsymbol{H}$ 作用于剩余子块 $\boldsymbol{F}_{k:m,k:d}$ 的各列和右端 $\boldsymbol{c}_{k:m}$，每个向量都按

$$\boldsymbol{z}\mapsto\boldsymbol{z}-\frac{2\boldsymbol{v}(\boldsymbol{v}^{\top}\boldsymbol{z})}{\boldsymbol{v}^{\top}\boldsymbol{v}}$$

计算，只需一次内积和一次向量更新；恒等变换时直接跳过。全部列完成后，取 $\boldsymbol{R}=\boldsymbol{F}_{1:d,1:d}$，检查对角元非零，再用回代求解 $\boldsymbol{R}\hat{\boldsymbol{x}}=\boldsymbol{c}_{1:d}$，输出 $\hat{\boldsymbol{x}}$；$\|\boldsymbol{c}_{d+1:m}\|_2$ 是最小残差范数。

示例 10.22　一步反射完成的三角化　取 $\boldsymbol{A} = \left[\begin{smallmatrix} 3 & 1 \\ 4 & 3 \\ 0 & 0 \end{smallmatrix}\right]$，$\boldsymbol{b} = (4,7,2)^{\mathsf{T}}$。首列 $\boldsymbol{y} = (3,4,0)^{\mathsf{T}}$ 的范数为 5，$y_1 > 0$，取 $s = 1$，于是 $\boldsymbol{v} = (8,4,0)^{\mathsf{T}}$，$\boldsymbol{v}^{\mathsf{T}}\boldsymbol{v} = 80$，$\tau = 1/40$，对应的反射矩阵为

$$\boldsymbol{H} = \boldsymbol{I} - \tfrac{1}{40}\boldsymbol{v}\boldsymbol{v}^{\mathsf{T}} = \begin{bmatrix} -\frac{3}{5} & -\frac{4}{5} & 0 \\ -\frac{4}{5} & \frac{3}{5} & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

逐列更新：第二列 $(1,3,0)^{\mathsf{T}}$ 与 $\boldsymbol{v}$ 的内积为 20，更新为 $(1,3,0)^{\mathsf{T}} - \frac{20}{40}(8,4,0)^{\mathsf{T}} = (-3,1,0)^{\mathsf{T}}$；右端与 $\boldsymbol{v}$ 的内积为 60，更新为 $(4,7,2)^{\mathsf{T}} - \frac{60}{40}(8,4,0)^{\mathsf{T}} = (-8,1,2)^{\mathsf{T}}$。于是

$$\boldsymbol{H}\boldsymbol{A} = \begin{bmatrix} -5 & -3 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}, \qquad \boldsymbol{H}\boldsymbol{b} = (-8,1,2)^{\mathsf{T}}.$$

第二列对角线下方已经为零，第二步取恒等变换。回代得 $\hat{x}_2 = 1$，$\hat{x}_1 = (-8 + 3\cdot 1)/(-5) = 1$；变换后右端的第三个分量 2 无法拟合，它就是最小残差范数。核验时，$\boldsymbol{H}^{\mathsf{T}}\boldsymbol{H} = \boldsymbol{I}$，原残差 $\boldsymbol{r} = \boldsymbol{b} - \boldsymbol{A}\hat{\boldsymbol{x}} = (0,0,2)^{\mathsf{T}}$ 满足 $\boldsymbol{A}^{\mathsf{T}}\boldsymbol{r} = \boldsymbol{0}$。这里 $\boldsymbol{R}$ 的对角元为负，不影响求解；若要统一成正对角，须把 $\boldsymbol{R}$ 的相应行与变换后右端的相应分量同时变号。

示例 10.23　直线拟合的 Householder 三角化　再用 Householder 变换处理示例 9.4的直线拟合，$\boldsymbol{A} = \left[\begin{smallmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{smallmatrix}\right]$、$\boldsymbol{b} = (1,2,2)^{\mathsf{T}}$，并与正规方程法对照。第一步 $\boldsymbol{y} = (1,1,1)^{\mathsf{T}}$，$\|\boldsymbol{y}\|_2 = \sqrt{3}$，$s = 1$，$\boldsymbol{v} = (1+\sqrt{3},1,1)^{\mathsf{T}}$，$\boldsymbol{v}^{\mathsf{T}}\boldsymbol{v} = 6 + 2\sqrt{3}$。第一列变为 $(-\sqrt{3},0,0)^{\mathsf{T}}$；第二列 $(0,1,2)^{\mathsf{T}}$ 与 $\boldsymbol{v}$ 的内积为 3，更新为 $(-\sqrt{3}, \frac{\sqrt{3}-1}{2}, \frac{\sqrt{3}+1}{2})^{\mathsf{T}}$；右端更新为 $(-\frac{5}{\sqrt{3}}, \frac{1}{\sqrt{3}}, \frac{1}{\sqrt{3}})^{\mathsf{T}}$。三个向量的长度平方仍为 3、5、9，与变换前相同，这是反射保持长度的直接检验。

第二步作用于后两行，$\boldsymbol{y} = (\frac{\sqrt{3}-1}{2}, \frac{\sqrt{3}+1}{2})^{\mathsf{T}}$，$\|\boldsymbol{y}\|_2 = \sqrt{2}$，反射后 $r_{2,2} = -\sqrt{2}$，右端后两分量变为 $(-\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{6}})^{\mathsf{T}}$。于是

$$\boldsymbol{R} = \begin{bmatrix} -\sqrt{3} & -\sqrt{3} \\ 0 & -\sqrt{2} \end{bmatrix}, \qquad \boldsymbol{c}_1 = \left(-\frac{5}{\sqrt{3}}, -\frac{1}{\sqrt{2}}\right)^{\mathsf{T}},$$

回代得 $\hat{x}_2 = 1/2$，$\hat{x}_1 = 5/3 - 1/2 = 7/6$，与示例 9.4一致；$|c_3| = 1/\sqrt{6}$ 正是最小残差范数。$\boldsymbol{R}$ 与示例 10.16的 Cholesky 因子 $\boldsymbol{L}^{\mathsf{T}}$ 只差各行的符号。

算法分析 单步消元的依据是下面的引理。

引理 10.24 Householder 反射 设 $\boldsymbol{y}\neq\boldsymbol{0}$，$\boldsymbol{v}$ 与 $\boldsymbol{H}$ 由式 (10.12)给出。则 $\boldsymbol{H}$ 对称正交，且 $\boldsymbol{H}\boldsymbol{y}=-s\|\boldsymbol{y}\|_2\boldsymbol{e}_1$。

证明 $\boldsymbol{H}$ 显然对称；$\boldsymbol{H}^2=\boldsymbol{I}-4\boldsymbol{v}\boldsymbol{v}^{\top}/(\boldsymbol{v}^{\top}\boldsymbol{v})+4\boldsymbol{v}(\boldsymbol{v}^{\top}\boldsymbol{v})\boldsymbol{v}^{\top}/(\boldsymbol{v}^{\top}\boldsymbol{v})^2=\boldsymbol{I}$，所以 $\boldsymbol{H}^{\top}\boldsymbol{H}=\boldsymbol{I}$。由 $s^2=1$ 与 $sy_1=|y_1|$，

$$\boldsymbol{v}^{\top}\boldsymbol{v}=2\|\boldsymbol{y}\|_2^2+2\|\boldsymbol{y}\|_2|y_1|=2\boldsymbol{v}^{\top}\boldsymbol{y}>0,$$

于是 $\boldsymbol{H}\boldsymbol{y}=\boldsymbol{y}-\boldsymbol{v}=-s\|\boldsymbol{y}\|_2\boldsymbol{e}_1$。 ■

每个 $\boldsymbol{H}$ 嵌入 m 阶后只作用于第 k 至 m 行；前 $k-1$ 列在这些行上已经是零，反射后仍为零。所以旧的零结构保持不变，d 步后 $\boldsymbol{F}=\boldsymbol{H}_d\cdots\boldsymbol{H}_1\boldsymbol{A}$ 是上三角矩阵，$\boldsymbol{c}=\boldsymbol{H}_d\cdots\boldsymbol{H}_1\boldsymbol{b}$。这正是取 $\boldsymbol{Q}^{\top}=\boldsymbol{H}_d\cdots\boldsymbol{H}_1$ 的 QR 分解，由定理 10.20，回代所得即最小二乘解。

符号 s 取与 y_1 相同，使 $\boldsymbol{v}$ 的首分量是两个同号数相加，避免了主要思想中指出的相消。Householder QR 后向稳定（第 14.1.2节），算出的 $\boldsymbol{Q}$ 在舍入误差范围内保持正交，主要工作约为 $2md^2-\frac{2}{3}d^3$ 次运算。列主元可以辅助辨认近相关的列，但秩亏时的最小范数选择仍回到第 10.8节。

10.7.6 Givens 旋转

主要思想 Householder 反射一次消去一整列的下方元素。若矩阵在对角线以下只有少数非零元, 更经济的做法是每次只消去一个指定元素。Givens **旋转**（Givens rotation）在两个坐标构成的平面内旋转，其余坐标不变；每次只混合两行，消去其中一个元素。图 10.5把旋转与反射并置。

先看二维问题：给定 $(\alpha,\beta)^{\top}\neq\boldsymbol{0}$，求旋转 $\boldsymbol{G}=\left[\begin{smallmatrix}c & s\\ -s & c\end{smallmatrix}\right]$，$c^2+s^2=1$，使 $\boldsymbol{G}(\alpha,\beta)^{\top}=(\rho,0)^{\top}$。第二个分量为零要求 $-s\alpha+c\beta=0$，即 (c,s) 与 (α,β) 平行；再由 $c^2+s^2=1$ 并取 $\rho>0$，得

$$\rho=\sqrt{\alpha^2+\beta^2},\qquad c=\alpha/\rho,\qquad s=\beta/\rho,$$
$$\boldsymbol{G}=\begin{bmatrix}c & s\\ -s & c\end{bmatrix}. \tag{10.13}$$

长度不变给出 $\rho=\sqrt{\alpha^2+\beta^2}$，也可以直接验证 $c\alpha+s\beta=(\alpha^2+\beta^2)/\rho=\rho$。这里的 s 与 Householder 反射中的符号无关。$\alpha=\beta=0$ 时取恒等变换。

对矩阵的两行 p,q 同时作用时，新的两行是

$$\text{第}p\text{行}\leftarrow c\cdot(\text{第}p\text{行})+s\cdot(\text{第}q\text{行}),\qquad \text{第}q\text{行}\leftarrow -s\cdot(\text{第}p\text{行})+c\cdot(\text{第}q\text{行}).$$

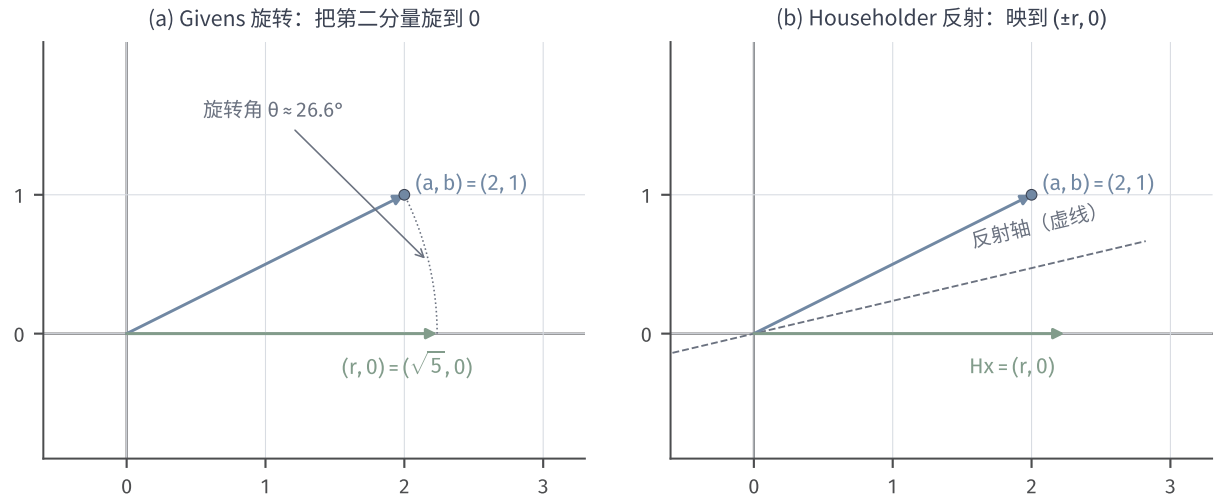


图 10.5 两种初等正交消元。左：Givens 旋转把 $(a,b)=(2,1)^{\top}$ 沿圆弧旋到 $(r,0)^{\top}$，$r=\sqrt{5}$，旋转角 $\theta=\arctan(1/2)$；右：Householder 反射沿角平分线把同一向量映到 $(r,0)^{\top}$。两者都是正交变换，保持长度，区别在旋转（行列式 $+1$）与反射（对称正交）。图中的反射取与式 (10.12)相反的符号，精确算术中两种选择都可以。解析式教学构造。

两式必须读取同一对旧行；若先覆盖第 p 行再用它计算第 q 行，结果就不再是旋转。右端的两个分量也按同样的方式更新。

算法实现与算例 输入满列秩的 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$（$m\ge d$）和 $\boldsymbol{b}\in\mathbb{R}^{m}$。先令 $\boldsymbol{F}=\boldsymbol{A}$、$\boldsymbol{t}=\boldsymbol{b}$，右端记作 $\boldsymbol{t}$ 是为了不与旋转参数 c 混淆。按 $k=1,\dots,d$ 处理各列；在第 k 列中按 $i=m,m-1,\dots,k+1$ 自下而上消去 $f_{i,k}$，每次使用相邻的第 $i-1$、i 两行。

每次消元先构造旋转：若 $f_{i,k}=0$，直接跳过；否则令 $\alpha=f_{i-1,k}$、$\beta=f_{i,k}$，按式 (10.13)计算 ρ,c,s。为避免上溢或下溢，平方和可以先除以 $\max(|\alpha|,|\beta|)$，开方后再恢复尺度，许多程序库以 hypot 函数提供这一计算；两分量同时为零的情形已在跳过时排除，不会出现除以零。

然后用同一个 $\boldsymbol{G}$ 左乘 $\boldsymbol{F}$ 的第 $i-1$、i 两行在第 k 列及以后的部分，并同步变换 $(t_{i-1},t_i)^{\top}$，计算时先用临时量保存两行的旧值。第 k 列的这两个元素由此变成 $(\rho,0)^{\top}$。接着继续向上消元，第 k 列完成后再进入下一列；保存旋转的顺序，就保存了 $\boldsymbol{Q}$。全部列完成后，取 $\boldsymbol{R}=\boldsymbol{F}_{1:d,1:d}$，用回代求解 $\boldsymbol{R}\hat{\boldsymbol{x}}=\boldsymbol{t}_{1:d}$，输出 $\hat{\boldsymbol{x}}$，并用原始数据检查残差。

新增观测时的更新最能体现局部消元的好处。设已经有 d 阶上三角的 $\boldsymbol{R}$ 和 $\boldsymbol{c}_1$，新到一条观测行 $\boldsymbol{w}^{\top}$ 及其右端 η。把新行排在 $\boldsymbol{R}$ 下方，依次用 $\boldsymbol{R}$ 的第 $1,\dots,d$ 行与它作旋转：第 k 次旋转消去新行的第 k 个元素，同时旋转 $\boldsymbol{c}_1$ 的第 k 个分量与新右端。d 次旋转后新行全为零，得到更新后的 $\boldsymbol{R}$ 与 $\boldsymbol{c}_1$，再回代即得新的 $\hat{\boldsymbol{x}}$。这一过程约需 $3d^2$ 次运算，也不需要旧的观测行；重新处理全部 $m+1$ 条观测则需 $O(md^2)$。

示例 10.25 一次旋转完成的三角化 沿用示例 10.22的 $\boldsymbol{A} = \left[\begin{smallmatrix} 3 & 1 \\ 4 & 3 \\ 0 & 0 \end{smallmatrix}\right]$ 与 $\boldsymbol{b} = (4, 7, 2)^{\mathsf{T}}$。第一列自下而上处理：$f_{3,1} = 0$，跳过；再用第 1、2 行消去 $f_{2,1} = 4$，$\alpha = 3$、$\beta = 4$，$\rho = 5$，$c = \frac{3}{5}$，$s = \frac{4}{5}$。第二列的两个元素更新为 $\frac{3}{5} \cdot 1 + \frac{4}{5} \cdot 3 = 3$ 与 $-\frac{4}{5} \cdot 1 + \frac{3}{5} \cdot 3 = 1$；右端更新为 $\frac{3}{5} \cdot 4 + \frac{4}{5} \cdot 7 = 8$ 与 $-\frac{4}{5} \cdot 4 + \frac{3}{5} \cdot 7 = 1$。第二列的 $f_{3,2} = 0$，跳过。

于是变换后的矩阵为 $\left[\begin{smallmatrix} 5 & 3 \\ 0 & 1 \\ 0 & 0 \end{smallmatrix}\right]$，右端为 $(8, 1, 2)^{\mathsf{T}}$，回代得 $\hat{\boldsymbol{x}} = (1, 1)^{\mathsf{T}}$，原残差仍为 $(0, 0, 2)^{\mathsf{T}}$。与示例 10.22对照，正交因子和 $\boldsymbol{R}$ 的对角符号不同，但解与最小残差相同。

示例 10.26 直线拟合的 Givens 三角化 仍取 $\boldsymbol{A} = \left[\begin{smallmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{smallmatrix}\right]$、$\boldsymbol{b} = (1, 2, 2)^{\mathsf{T}}$，把右端写在增广列中。第一列先用第 2、3 行消去 $f_{3,1}$：$\alpha = \beta = 1$，$\rho = \sqrt{2}$，$c = s = 1/\sqrt{2}$，两行变为 $(\sqrt{2}, \frac{3}{\sqrt{2}} \mid 2\sqrt{2})$ 与 $(0, \frac{1}{\sqrt{2}} \mid 0)$。再用第 1、2 行消去 $f_{2,1} = \sqrt{2}$：$\rho = \sqrt{3}$，$c = 1/\sqrt{3}$，$s = \sqrt{2/3}$，两行变为 $(\sqrt{3}, \sqrt{3} \mid \frac{5}{\sqrt{3}})$ 与 $(0, \sqrt{3/2} \mid \sqrt{2/3})$。

第二列用第 2、3 行消去 $f_{3,2} = 1/\sqrt{2}$：$\rho = \sqrt{2}$，$c = \sqrt{3}/2$，$s = 1/2$，两行变为 $(0, \sqrt{2} \mid \frac{1}{\sqrt{2}})$ 与 $(0, 0 \mid -\frac{1}{\sqrt{6}})$。于是 $\boldsymbol{R} = \left[\begin{smallmatrix} \sqrt{3} & \sqrt{3} \\ 0 & \sqrt{2} \end{smallmatrix}\right]$，$\boldsymbol{t}_{1:2} = (5/\sqrt{3}, 1/\sqrt{2})^{\mathsf{T}}$，回代得 $\hat{\boldsymbol{x}} = (7/6, 1/2)^{\mathsf{T}}$。三次旋转后 $\boldsymbol{R}$ 恰为 Cholesky 因子 $\boldsymbol{L}^{\mathsf{T}}$，$|t_3| = 1/\sqrt{6}$ 为最小残差范数。

算法分析 每次旋转满足 $c^2 + s^2 = 1$，所以 $\boldsymbol{G}$ 正交，并且 $c\alpha + s\beta = \rho$、$-s\alpha + c\beta = 0$。处理第 k 列时，参与旋转的两行在前 $k-1$ 列上已经是零，旋转后仍为零；在第 k 列内，第 i 行被消零以后，后续旋转只涉及更上面的行对，不再改动它。因此新零不会被后续旋转破坏，结束时 $\boldsymbol{F}$ 是上三角矩阵，$\boldsymbol{t}$ 是对 $\boldsymbol{b}$ 施加同一串旋转的结果，由定理 10.20，回代所得即最小二乘解。

Givens QR 同样后向稳定（第 14.1.2节）。稠密时第 k 列需要 $m-k$ 次旋转，总工作约为 $3md^2 - d^3$ 次运算，约为 Householder 的 1.5 倍；带状、上 Hessenberg 或局部更新的问题需要的旋转少得多，代价随之降低。可见 Givens 与 Householder 的选择依据是矩阵结构与更新方式：稠密矩阵一次性分解用 Householder 更省，局部结构和逐行更新用 Givens 更合适。

10.8 SVD 求解

秩亏或秩未知时，正规方程与 QR 回代都不再适用。本节以最小二乘解中的最小范数解为目标，依次讲清 SVD 求解的主要思想、算法实现和算法分析，再分别讨论加权最小二乘与齐次最小二乘。SVD 的形式已在第 5章

建立；数值分解调用直接作用于 $\boldsymbol{A}$ 的 SVD 过程，本节只说明取得因子后怎样得到解，重点是由分解构造解，而不是重新证明分解存在。

10.8.1 主要思想

SVD 在输入端和输出端各给出一组标准正交方向。在这两组坐标下，$\boldsymbol{A}$ 只是把第 i 个输入坐标乘以 σ_i，送到第 i 个输出坐标。于是把可拟合的输出坐标除以对应的正奇异值，就得到产生它们所需的输入坐标；零空间方向的坐标不影响拟合值，令它们为零，就得到范数最小的解。图 10.6画出了这一坐标变换。

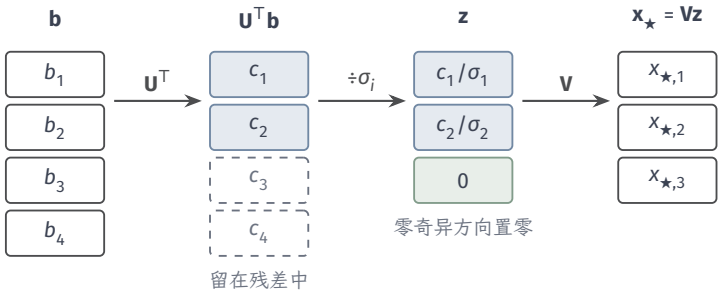


图 10.6 SVD 求解的坐标变换，示意 $m=4$、$d=3$、$r=2$。右端先变到左奇异坐标，蓝色的前 r 个坐标可以拟合，虚线框中的其余坐标无论怎样选 $\boldsymbol{x}$ 都留在残差中；可拟合坐标除以对应奇异值，零奇异方向的坐标取零；最后由右奇异向量还原为原变量。

目标在奇异坐标下分离 设 $\operatorname{rank}\boldsymbol{A}=r$，写完整的奇异值分解 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$，其中 $\boldsymbol{U}\in\mathbb{R}^{m\times m}$ 与 $\boldsymbol{V}\in\mathbb{R}^{d\times d}$ 正交，$\boldsymbol{\Sigma}$ 的前 r 个对角元 $\sigma_1\geq\cdots\geq\sigma_r>0$，其余为零。令 $\boldsymbol{z}=\boldsymbol{V}^{\top}\boldsymbol{x}$、$\boldsymbol{c}=\boldsymbol{U}^{\top}\boldsymbol{b}$。由 $\boldsymbol{U}^{\top}$ 保持长度，

$$\|\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}\|_2^2=\|\boldsymbol{c}-\boldsymbol{\Sigma}\boldsymbol{z}\|_2^2=\sum_{i=1}^{r}(c_i-\sigma_i z_i)^2+\sum_{i=r+1}^{m}c_i^2.$$

输入坐标 $z_{r+1},\dots,z_d$ 根本不出现在目标中。

逐个坐标求解 各平方项互不耦合，可以分别取最小。对每个正奇异值令 $c_i-\sigma_i z_i=0$，得 $z_i=c_i/\sigma_i$；输出端 $i>r$ 的分量 c_i 无论怎样选 $\boldsymbol{x}$ 都留在残差中。所以最小二乘解的全部自由度恰好是输入零空间方向上的坐标 $z_{r+1},\dots,z_d$。

取最小范数 再由 $\|\boldsymbol{x}\|_2=\|\boldsymbol{V}\boldsymbol{z}\|_2=\|\boldsymbol{z}\|_2$，令全部自由坐标为零就使范数最小，得到

$$\boldsymbol{x}_{\star}=\sum_{i=1}^{r}\frac{\boldsymbol{u}_i^{\top}\boldsymbol{b}}{\sigma_i}\boldsymbol{v}_i.$$

这给出了执行顺序：先把右端投影到输出奇异方向，再对正奇异值取逆，最后由输入奇异方向重建。

10.8.2 算法实现

输入 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$ 与 $\boldsymbol{b} \in \mathbb{R}^m$，不要求满秩，输出最小范数最小二乘解 $\boldsymbol{x}_\star$，没有额外需要选定的规则。这里按精确的秩 r 描述求解；有限精度下怎样判定数值秩，以及是否截断小奇异值，属于第 14章的内容（第 14.1.4节与第 14.2.2节）。

计算 SVD 第一步调用数值 SVD 过程，按第 5章的形式取得 $\boldsymbol{A} = \boldsymbol{U}_r \boldsymbol{\Sigma}_r \boldsymbol{V}_r^{\top}$。其中 $r = \operatorname{rank} \boldsymbol{A}$，$\boldsymbol{U}_r = [\boldsymbol{u}_1, \dots, \boldsymbol{u}_r]$ 与 $\boldsymbol{V}_r = [\boldsymbol{v}_1, \dots, \boldsymbol{v}_r]$ 的列标准正交，$\boldsymbol{\Sigma}_r = \operatorname{diag}(\sigma_1, \dots, \sigma_r)$ 且各 $\sigma_i > 0$。若 $\boldsymbol{A} = \boldsymbol{0}$，则直接取 $\boldsymbol{x}_\star = \boldsymbol{0}$ 并结束。

投影右端 然后计算 $\boldsymbol{c} = \boldsymbol{U}_r^{\top} \boldsymbol{b}$，即 $c_i = \boldsymbol{u}_i^{\top} \boldsymbol{b}$，$i = 1, \dots, r$。这一步把右端投影到能够拟合的输出方向上；$\boldsymbol{b}$ 在其余方向上的部分，无论怎样选 $\boldsymbol{x}$ 都会留在残差中。

按奇异值缩放 接着对每个 $i = 1, \dots, r$ 计算 $z_i = c_i / \sigma_i$，得到产生这些输出所需的输入坐标。除法只对正奇异值进行，零奇异值对应的方向不参与。

还原原变量 最后计算

$$\boldsymbol{x}_\star = \boldsymbol{V}_r \boldsymbol{z} = \sum_{i=1}^{r} \frac{\boldsymbol{u}_i^{\top} \boldsymbol{b}}{\sigma_i} \boldsymbol{v}_i$$

并输出，把奇异坐标还原为原变量。整个过程只用到因子对向量的作用，无需形成完整的伪逆。

示例 10.27　秩一矩阵的 SVD 求解 取 $\boldsymbol{A} = \left[\begin{smallmatrix} 1 & 1 \\ 1 & 1 \end{smallmatrix}\right]$、$\boldsymbol{b} = (1, 3)^{\top}$。两个方程要求 $x_1 + x_2$ 同时等于 1 和 3，方程不相容；$\boldsymbol{A}$ 的秩为 1，解也不唯一。唯一的正奇异值为 $\sigma_1 = 2$，$\boldsymbol{u}_1 = \boldsymbol{v}_1 = (1, 1)^{\top} / \sqrt{2}$。按投影、缩放、还原三步，得 $c_1 = \boldsymbol{u}_1^{\top} \boldsymbol{b} = 2\sqrt{2}$，$z_1 = c_1 / \sigma_1 = \sqrt{2}$，$\boldsymbol{x}_\star = z_1 \boldsymbol{v}_1 = (1, 1)^{\top}$。

两次选择都可以核对。拟合值 $\boldsymbol{A}\boldsymbol{x}_\star = (2, 2)^{\top}$ 取两个观测的平均，残差 $(-1, 1)^{\top}$ 与列空间方向 $(1, 1)^{\top}$ 正交，长度 $\sqrt{2}$ 等于 $\boldsymbol{b}$ 在被舍弃方向 $\boldsymbol{u}_2 = (1, -1)^{\top} / \sqrt{2}$ 上的分量的绝对值。另一方面，$\boldsymbol{x}_\star$ 与核方向 $(1, -1)^{\top}$ 正交：全部最小二乘解为 $(1 + t, 1 - t)^{\top}$，其中 $t = 0$ 时范数最小。

上例是方阵，输出端被舍弃的只有一个方向。下例的矩阵更高，输出端有两个方向无法拟合，用来分别观察两类被舍弃的分量。

示例 10.28　秩亏且不相容的高矩阵　取 $\boldsymbol{A}=\left[\begin{smallmatrix}1&1\\0&0\\0&0\end{smallmatrix}\right]$、$\boldsymbol{b}=(2,1,0)^{\top}$。唯一的正奇异值为 $\sigma_1=\sqrt{2}$，对应 $\boldsymbol{u}_1=(1,0,0)^{\top}$、$\boldsymbol{v}_1=(1,1)^{\top}/\sqrt{2}$。投影得 $c_1=2$，缩放得 $z_1=2/\sqrt{2}=\sqrt{2}$，重建得 $\boldsymbol{x}_\star=\sqrt{2}\,\boldsymbol{v}_1=(1,1)^{\top}$。

输出端的第二、三个坐标属于不可拟合部分，其中第二个坐标留下残差 $\boldsymbol{r}=\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_\star=(0,1,0)^{\top}$。输入端的零空间为 $\operatorname{span}\{(1,-1)^{\top}\}$，全部最小二乘解为 $(1+t,1-t)^{\top}$，范数平方为 $2+2t^2$，所选的 $t=0$ 确为最小。用原矩阵核验：$\boldsymbol{A}^{\top}\boldsymbol{r}=\boldsymbol{0}$ 说明是最小二乘解，$\boldsymbol{x}_\star\perp(1,-1)^{\top}$ 说明是最小范数代表。

10.8.3　算法分析

正确性　上述四步算出的正是伪逆作用于右端的结果。

定理 10.29　SVD 求解给出 $\boldsymbol{A}^{\dagger}\boldsymbol{b}$　对任意 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$ 与 $\boldsymbol{b}\in\mathbb{R}^{m}$，上述过程的输出 $\boldsymbol{x}_\star=\boldsymbol{A}^{\dagger}\boldsymbol{b}$，它是唯一的最小范数最小二乘解。

证明　由式 (9.9)，$\boldsymbol{A}^{\dagger}\boldsymbol{b}=\sum_{i\le r}\boldsymbol{v}_i\boldsymbol{u}_i^{\top}\boldsymbol{b}/\sigma_i$，与输出相同；$\boldsymbol{A}=\boldsymbol{0}$ 时两者都是 $\boldsymbol{0}$。最优性由定理 9.9给出。也可以直接验证：残差 $\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_\star=\boldsymbol{b}-\boldsymbol{U}_r\boldsymbol{U}_r^{\top}\boldsymbol{b}$ 与列空间正交，所以 $\boldsymbol{x}_\star$ 满足正规方程；$\boldsymbol{x}_\star\in\operatorname{range}(\boldsymbol{V}_r)=(\ker\boldsymbol{A})^{\perp}$，由定理 9.6，它在全部最小二乘解中范数最小。 ■

数值敏感度　敏感性来自除以小奇异值。固定 $\boldsymbol{A}$ 且 $r>0$ 时，右端扰动 $\delta\boldsymbol{b}$ 使解改变 $\sum_{i=1}^{r}(\boldsymbol{u}_i^{\top}\delta\boldsymbol{b})\boldsymbol{v}_i/\sigma_i$，其长度至多为 $\|\delta\boldsymbol{b}\|_2/\sigma_r$，即放大倍数至多为 $1/\sigma_r$。稳定地算出 SVD 并不能消除问题本身的病态：分解残差很小，恢复出的系数仍可能被观测误差严重放大。若为了压低放大而截去真实的正奇异值，求的就已不是 $\boldsymbol{A}^{\dagger}\boldsymbol{b}$，这属于第 14章的截断 SVD 与正则化。

10.8.4　加权最小二乘

主要思想　第 9.5节的加权最小二乘以对称正定的权矩阵 $\boldsymbol{M}\in\mathbb{R}^{m\times m}$ 规定目标函数 $(\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b})^{\top}\boldsymbol{M}(\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b})$。核心做法是把权矩阵写成 $\boldsymbol{M}=\boldsymbol{R}^{\top}\boldsymbol{R}$，于是目标函数等于 $\|\boldsymbol{R}\boldsymbol{A}\boldsymbol{x}-\boldsymbol{R}\boldsymbol{b}\|_2^2$，用同一个 $\boldsymbol{R}$ 变换 $\boldsymbol{A}$ 和 $\boldsymbol{b}$ 后，就成为普通最小二乘。若 Cholesky 分解写作 $\boldsymbol{M}=\boldsymbol{L}\boldsymbol{L}^{\top}$，这里必须取 $\boldsymbol{R}=\boldsymbol{L}^{\top}$，才有 $\boldsymbol{R}^{\top}\boldsymbol{R}=\boldsymbol{L}\boldsymbol{L}^{\top}$；取 $\boldsymbol{R}=\boldsymbol{L}$ 则得到 $\boldsymbol{L}^{\top}\boldsymbol{L}$，一般不等于 $\boldsymbol{M}$。

变换只作用于观测端，未知量 $\boldsymbol{x}$ 本身没有改变。因此对 $\widetilde{\boldsymbol{A}}=\boldsymbol{R}\boldsymbol{A}$、$\widetilde{\boldsymbol{b}}=\boldsymbol{R}\boldsymbol{b}$ 调用 SVD 求解，得到的 $\widetilde{\boldsymbol{A}}^{\dagger}\widetilde{\boldsymbol{b}}$ 是加权最小二乘解中欧氏范数最小的代表。权矩阵度量的是残差，不是系数，所以不能再把它当成系数范数的权重。

算法实现与算例 输入 $\boldsymbol{A}$、$\boldsymbol{b}$ 与权矩阵 $\boldsymbol{M}$，输出加权最小二乘解中欧氏范数最小的代表 $\boldsymbol{x}_\star$。第一步构造权因子：用第 10.2节的方法作 Cholesky 分解 $\boldsymbol{M}=\boldsymbol{L}\boldsymbol{L}^{\top}$，取 $\boldsymbol{R}=\boldsymbol{L}^{\top}$；对角权 $\boldsymbol{M}=\operatorname{diag}(w_1,\dots,w_m)$ 则直接取 $\boldsymbol{R}=\operatorname{diag}(\sqrt{w_1},\dots,\sqrt{w_m})$。若权以 $\boldsymbol{M}=\boldsymbol{\Gamma}^{-1}$ 的形式给出，$\boldsymbol{\Gamma}$ 为对称正定矩阵（例如观测误差的协方差），就改为分解 $\boldsymbol{\Gamma}=\boldsymbol{L}\boldsymbol{L}^{\top}$，这时 $\boldsymbol{M}=\boldsymbol{L}^{-\top}\boldsymbol{L}^{-1}$，取 $\boldsymbol{R}=\boldsymbol{L}^{-1}$。

第二步白化数据，计算 $\widetilde{\boldsymbol{A}}=\boldsymbol{R}\boldsymbol{A}$ 和 $\widetilde{\boldsymbol{b}}=\boldsymbol{R}\boldsymbol{b}$。在 $\boldsymbol{M}=\boldsymbol{\Gamma}^{-1}$ 的形式下，对 $\boldsymbol{A}$ 的各列和 $\boldsymbol{b}$ 用前代求解 $\boldsymbol{L}\widetilde{\boldsymbol{A}}=\boldsymbol{A}$ 与 $\boldsymbol{L}\widetilde{\boldsymbol{b}}=\boldsymbol{b}$，不显式求逆。

第三步对 $(\widetilde{\boldsymbol{A}},\widetilde{\boldsymbol{b}})$ 调用上面的 SVD 求解过程，得到 $\boldsymbol{x}_\star$ 并输出；$\widetilde{\boldsymbol{A}}$ 满列秩时也可以调用第 10.7节的 QR 求解。未知量的坐标没有改变，无须另做恢复。最后用原始数据检查加权正规残差 $\boldsymbol{A}^{\top}\boldsymbol{M}(\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_\star)=\boldsymbol{0}$，需要最小范数时再检查 $\boldsymbol{x}_\star\perp\ker\boldsymbol{A}$。

示例 10.30　两种权重下的白化求解 沿用示例 9.13的 $\boldsymbol{A}=(1,1)^{\top}$、$\boldsymbol{b}=(2,1)^{\top}$、$\boldsymbol{M}=\operatorname{diag}(1,4)$。对角权不必作 Cholesky 分解，直接取 $\boldsymbol{R}=\operatorname{diag}(1,2)$，白化得 $\widetilde{\boldsymbol{A}}=(1,2)^{\top}$、$\widetilde{\boldsymbol{b}}=(2,2)^{\top}$。$\widetilde{\boldsymbol{A}}$ 只有一列，QR 因子为 $\boldsymbol{q}=(1,2)^{\top}/\sqrt{5}$、$r=\sqrt{5}$，于是 $c_1=\boldsymbol{q}^{\top}\widetilde{\boldsymbol{b}}=6/\sqrt{5}$，回代得 $x_\star=c_1/r=6/5$，与该示例中加权正规方程 $5a=6$ 的解一致。

若取等权 $\boldsymbol{M}=\boldsymbol{I}$，则 $\boldsymbol{R}=\boldsymbol{I}$，同样的步骤由 $\boldsymbol{q}=(1,1)^{\top}/\sqrt{2}$、$r=\sqrt{2}$、$c_1=3/\sqrt{2}$ 给出欧氏解 $3/2$。两种权重只改变送入求解器的数据，QR 求解的步骤完全相同。

上例满列秩，加权解唯一。下例秩亏，用来同时观察权重怎样改变最佳拟合值，以及伪逆怎样在加权解中选出最小范数的系数。

示例 10.31　秩亏的加权最小二乘 取 $\boldsymbol{A}=\left[\begin{smallmatrix}1&1\\1&1\end{smallmatrix}\right]$、$\boldsymbol{b}=(0,2)^{\top}$、$\boldsymbol{M}=\operatorname{diag}(1,3)$。取 $\boldsymbol{R}=\operatorname{diag}(1,\sqrt{3})$，白化得 $\widetilde{\boldsymbol{A}}=\left[\begin{smallmatrix}1&1\\1/\sqrt{3}&1/\sqrt{3}\end{smallmatrix}\right]$、$\widetilde{\boldsymbol{b}}=(0,2\sqrt{3})^{\top}$。$\widetilde{\boldsymbol{A}}$ 的秩为 1，唯一的正奇异值为 $2\sqrt{2}$，左、右奇异向量分别为 $\tilde{\boldsymbol{u}}_1=(1,\sqrt{3})^{\top}/2$ 与 $\tilde{\boldsymbol{v}}_1=(1,1)^{\top}/\sqrt{2}$。

投影系数为 $\tilde{\boldsymbol{u}}_1^{\top}\widetilde{\boldsymbol{b}}=3$，除以 $2\sqrt{2}$ 再重建，得 $\boldsymbol{x}_\star=\frac{3}{2\sqrt{2}}\cdot\frac{1}{\sqrt{2}}(1,1)^{\top}=(\frac{3}{4},\frac{3}{4})^{\top}$。拟合值为 $(\frac{3}{2},\frac{3}{2})^{\top}$：两个观测的拟合值相同，取的是 0 与 2 按权重 $1:3$ 的加权平均，而不是普通平均 1。原残差为 $\boldsymbol{r}=(-\frac{3}{2},\frac{1}{2})^{\top}$，$\boldsymbol{M}\boldsymbol{r}=(-\frac{3}{2},\frac{3}{2})^{\top}$，所以 $\boldsymbol{A}^{\top}\boldsymbol{M}\boldsymbol{r}=\boldsymbol{0}$，加权残差平方为 $\frac{9}{4}+3\cdot\frac{1}{4}=3$。系数差的方向 $(1,-1)^{\top}$ 张成 $\ker\boldsymbol{A}$，$\boldsymbol{x}_\star$ 在这个方向上的分量为零。

算法分析 由第 9.5节，变换前后的目标函数逐点相等，即 $(\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b})^{\top}\boldsymbol{M}(\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b})=\|\widetilde{\boldsymbol{A}}\boldsymbol{x}-\widetilde{\boldsymbol{b}}\|_2^2$；未知量及其欧氏范数也没有变，所以两个问题的最优解集与最小范数代表都相同（定理 9.12）。又 $\boldsymbol{R}$ 可逆，$\ker\widetilde{\boldsymbol{A}}=\ker\boldsymbol{A}$，所以

$\boldsymbol{x}_\star \perp \ker \boldsymbol{A}$。数值敏感度取决于 $\widetilde{\boldsymbol{A}} = \boldsymbol{R}\boldsymbol{A}$ 而不是 $\boldsymbol{A}$：权重可能改善条件，也可能使它变差，应在变换后的系统上判断。

10.8.5 齐次最小二乘

主要思想 第 9.6节的齐次最小二乘在 $\|\boldsymbol{x}\|_2 = 1$ 的约束下最小化 $\|\boldsymbol{A}\boldsymbol{x}\|_2$。它是 $\boldsymbol{b} = \boldsymbol{0}$ 的情形，单位长度约束属于求解目标，用来排除无意义的零解。核心做法是选择被 $\boldsymbol{A}$ 伸缩得最小的方向。

用完整的右奇异基 $\boldsymbol{V} = [\boldsymbol{v}_1, \dots, \boldsymbol{v}_d]$ 写 $\boldsymbol{x} = \boldsymbol{V}\boldsymbol{z}$。记 $\hat{\sigma}_i = \|\boldsymbol{A}\boldsymbol{v}_i\|_2$ 为第 i 个方向的伸缩量：$i \le \min(m, d)$ 时它是第 i 个奇异值（可以为零），$m < d$ 时多出的 $d - m$ 个方向属于零空间，伸缩量为零。因为各 $\boldsymbol{A}\boldsymbol{v}_i$ 两两正交，

$$\|\boldsymbol{x}\|_2^2 = \sum_{i=1}^{d} z_i^2 = 1, \qquad \|\boldsymbol{A}\boldsymbol{x}\|_2^2 = \sum_{i=1}^{d} \hat{\sigma}_i^2 z_i^2.$$

目标是平方伸缩量 $\hat{\sigma}_i^2$ 以 z_i^2 为权的加权平均，所以最小值等于其中最小的一个，并且当且仅当 $\boldsymbol{z}$ 只落在取得最小伸缩量的那些坐标上时达到。最小伸缩量是单重的时，实数域中的最优方向仍有 $\pm\boldsymbol{v}_d$ 两个；重数大于一或零空间多于一维时，应报告整个最优子空间，而不是声称有唯一的向量。

算法实现与算例 输入 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$，没有额外需要选定的规则，输出使 $\|\boldsymbol{A}\boldsymbol{x}\|_2$ 最小的单位向量 $\hat{\boldsymbol{x}}$。第一步调用数值 SVD 过程，取得第 5章中的完整右因子 $\boldsymbol{V}$，各列按伸缩量从大到小排列，并检查输入维数与秩。$m < d$ 时奇异值只有 m 个，完整右基中多出的方向属于零空间，也要保留；薄 SVD 可能没有列出全部右零空间，必须补齐相应的基，不能机械地取薄 SVD 的最后一列。这些方向直接从 $\boldsymbol{A}$ 的 SVD 取得，不通过显式形成 $\boldsymbol{A}^{\mathsf{T}}\boldsymbol{A}$ 再求特征向量。

第二步取 $\hat{\boldsymbol{x}} = \boldsymbol{v}_d$ 并输出：存在零空间时它是零空间中的单位向量，否则是最小正奇异值的右奇异向量。它已经是单位向量，无须再归一化。最小伸缩量重复时，$\boldsymbol{v}_d$ 只是最优子空间中的一个选择；$\hat{\boldsymbol{x}}$ 与 $-\hat{\boldsymbol{x}}$ 表示同一组参数比例。

示例 10.32 齐次最小二乘的两种情形 先取 $\boldsymbol{A} = \left[\begin{smallmatrix} 3 & 0 \\ 0 & 1 \\ 0 & 0 \end{smallmatrix}\right]$。目标为 $\|\boldsymbol{A}\boldsymbol{x}\|_2^2 = 9x_1^2 + x_2^2$，约束为 $x_1^2 + x_2^2 = 1$；目标等于 $1 + 8x_1^2$，在 $x_1 = 0$ 时最小，故 $\hat{\boldsymbol{x}} = (0, \pm 1)^{\mathsf{T}}$，最小残差范数为 1，对应最小奇异值 1 的右奇异向量。零向量虽然给出零残差，却不满足单位长度约束。

再取 $\boldsymbol{A} = \left[\begin{smallmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \end{smallmatrix}\right]$。两个正奇异值为 2 和 1，薄 SVD 只列出 $\boldsymbol{e}_2$ 与 $\boldsymbol{e}_1$ 两个右奇异向量；补齐完整右基后还有 $\boldsymbol{e}_3$，它满足 $\boldsymbol{A}\boldsymbol{e}_3 = \boldsymbol{0}$，最小残

差为零。若只看两个正奇异值而取 $\boldsymbol{e}_1$，得到的残差范数为 1，漏掉了真正的最小方向。

算法分析 正确性直接来自定理 9.14：$\|\boldsymbol{A}\boldsymbol{x}\|_2^2 = \boldsymbol{x}^{\top}\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{x}$ 在单位球面上的最小值是 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 的最小特征值，由对应的特征向量达到，而 $\boldsymbol{v}_d$ 正是这样的向量；主要思想中的加权平均论证给出了同一结论。最优方向的敏感度由最小特征值与其余谱之间的间隙控制，可用第 7.2.3节的子空间扰动界估计；最小特征值重复时，不能保证单个方向唯一。单位长度与最优性的检验按第 9.7节进行。

10.9 方法选择与结果检验

前面各节分别给出了一种直接法。面对具体问题时，要先回到第 9章确定的求解目标，再看矩阵结构，最后用原始数据核验算出的结果。本节按这一顺序归纳，并在同一组数据上比较几条路线。

按目标与结构选择 求精确解时，非奇异方阵用带部分选主元的 LU，对称正定矩阵用 Cholesky，对称不定但非奇异的矩阵用分块 LDL。求最小二乘解时，满列秩用 QR，条件数适中、需要按行累计数据时也可用正规方程法；满行秩欠定方程的最小范数解用转置 QR；秩亏或秩未知的一般情形用 SVD。加权目标先白化再按普通情形求解，齐次目标取最小伸缩方向。

分块消元与低秩更新不是新的分解，而是复用上面的求解步骤，各有成立条件。分块消元要求被消块 $\boldsymbol{B}$ 可逆，并且只有在 $\boldsymbol{B}$ 易于求解或保留块较小时才省事（第 10.4节）；整个问题是否唯一可解，由 Schur 补 $\boldsymbol{S}$ 是否非奇异决定。低秩更新要求旧矩阵的分解已经存在、修改的秩远小于阶数，并且辅助矩阵 $\boldsymbol{K}$ 可逆且不太病态（第 10.5节）；连续多次更新后，应与重新分解比较代价和精度。

同一组数据上的比较 沿用示例 9.4的直线拟合 $\boldsymbol{A} = \left[\begin{smallmatrix}1&0\\1&1\\1&2\end{smallmatrix}\right]$、$\boldsymbol{b} = (1,2,2)^{\top}$。正规方程法（示例 10.16）形成 $\boldsymbol{G} = \left[\begin{smallmatrix}3&3\\3&5\end{smallmatrix}\right]$，得到 Cholesky 因子 $\boldsymbol{L}$ 与前代结果 $\boldsymbol{y} = (5/\sqrt{3}, 1/\sqrt{2})^{\top}$；Givens 路线（示例 10.26）得到 $\boldsymbol{R} = \boldsymbol{L}^{\top}$ 与 $\boldsymbol{c}_1 = \boldsymbol{y}$，Householder 路线（示例 10.23）得到的 $\boldsymbol{R}$ 与 $\boldsymbol{c}_1$ 只差各行的符号。三条路线最后回代的是同一个三角方程，给出同一个 $\hat{\boldsymbol{x}} = (7/6, 1/2)^{\top}$；区别在得到这个方程的方式，正规方程法要先形成 $\boldsymbol{A}^{\top}\boldsymbol{A}$，正交方法不需要。

复制常数列后得到 $\widetilde{\boldsymbol{A}} = \left[\begin{smallmatrix}1&0&1\\1&1&1\\1&2&1\end{smallmatrix}\right]$，列空间和最优残差都不变，但秩降为 2，正规方程与 QR 回代都会遇到零主元。SVD 求解略去 $\sigma_3 = 0$ 对应的方向 $(1,0,-1)^{\top}/\sqrt{2}$，得到最小范数解 $\boldsymbol{x}_\star = (7/12, 1/2, 7/12)^{\top}$：最小二乘只

约束 $x_1 + x_3 = 7/6$ 与 $x_2 = 1/2$，最小范数再把 $7/6$ 平分给两个相同的列。前一组比较的差别在计算方式，这里的差别则在选解目标。

用原始数据核验　算出 $\boldsymbol{x}$ 后，要代回原问题检查它是否符合目标，而不只检查中间的小系统。精确解检查 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$，普通最小二乘解检查 $\boldsymbol{A}^{\top}(\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}) = \boldsymbol{0}$，要求最小范数时再检查 $\boldsymbol{x} \perp \ker \boldsymbol{A}$。在上例中，残差 $(-\frac{1}{6}, \frac{1}{3}, -\frac{1}{6})^{\top}$ 不为零，但它与 $\boldsymbol{A}$ 的两列都正交；$\widetilde{\boldsymbol{A}}\boldsymbol{x}_{\star} = \boldsymbol{A}\hat{\boldsymbol{x}}$，且 $\boldsymbol{x}_{\star}$ 与核方向 $(1, 0, -1)^{\top}$ 正交。加权问题使用第 9.7节的加权正交条件 $\boldsymbol{A}^{\top}\boldsymbol{M}(\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}) = \boldsymbol{0}$，齐次问题检查单位长度以及是否为最小伸缩方向。最小二乘的残差本来就可以非零；这些量用于核对计算过程，各求解算法仍只返回 $\boldsymbol{x}$。

计算中还可以用分解残差（如 $\|\boldsymbol{A} - \boldsymbol{L}\boldsymbol{U}\|$、$\|\boldsymbol{A} - \boldsymbol{Q}_1\boldsymbol{R}\|$）和正交性（如 $\|\boldsymbol{Q}_1^{\top}\boldsymbol{Q}_1 - \boldsymbol{I}\|$）分别核对中间变换，但这些检查只是旁证，不属于算法本身，也不能代替对原问题的检验。

残差小不等于误差小　即使上述检验都通过，也不保证 $\boldsymbol{x}$ 的误差小：矩阵接近奇异时，很小的残差可能对应很大的解误差。本章只给出了算法层面的结论：部分选主元控制乘子但不排除主元增长，Cholesky 没有增长问题，正规方程使条件数平方，正交变换保持长度，SVD 把小奇异值的放大暴露为 $1/\sigma_r$。第 14章用条件数与前向、后向误差系统地解释这些现象（第 14.1节），并在直接法与迭代法之间作整体比较（第 14.3节）。

10.10　本章小结

本章回答了章首的问题：求解目标确定以后，怎样不求逆、在有限步内把选定的解算出来。共同的做法是把原问题化为容易求解的问题，并把分解与右端的处理分开，使同一次分解可以服务于多个右端。

对方阵的精确解，消元把求解化为前代与回代。一般非奇异方阵用带部分选主元的 LU 分解 $\boldsymbol{P}\boldsymbol{A} = \boldsymbol{L}\boldsymbol{U}$，乘子按位置存入 $\boldsymbol{L}$，后续换行时已存乘子要随行交换；部分选主元对任何非奇异矩阵都能进行，不选主元则要求各顺序主子式非零。

利用对称性可以减少一半的工作。对称正定矩阵用 Cholesky 分解 $\boldsymbol{A} = \boldsymbol{L}\boldsymbol{L}^{\top}$，每一列的开方量是一个 Schur 补，正定性恰好保证它为正；分解存在且唯一当且仅当矩阵对称正定，运算量是 LU 的一半。对称不定矩阵用分块 LDL 分解 $\boldsymbol{P}\boldsymbol{A}\boldsymbol{P}^{\top} = \boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\top}$，负主元保留在 $\boldsymbol{D}$ 中，零对角元时改用二阶块，使可逆的矩阵总能继续消元。

块结构和低秩修改让这些分解得以复用。分块消元先用被消块 $\boldsymbol{B}$ 的因子求出 $\boldsymbol{Z}$ 与 $\boldsymbol{z}$，再解 Schur 补方程 $\boldsymbol{S}\boldsymbol{v} = \boldsymbol{h}$；$\boldsymbol{B}$ 可逆时，原矩阵非奇异当且仅当 $\boldsymbol{S}$ 非奇异，对称时正定性也传给 $\boldsymbol{S}$。低秩更新把修改的影响集中到 k

维辅助量上，只需旧因子上的 $k+1$ 次求解和一个 k 阶方程；更新后的矩阵可逆当且仅当辅助矩阵 $\boldsymbol{K}$ 可逆，Woodbury 恒等式和 Sherman–Morrison 公式是这一等价关系的矩阵形式。两者的节省都有条件：被消块易解，或者已有分解且修改秩很小。

对最小二乘与最小范数问题，三条路线的区别在于怎样处理 $\boldsymbol{A}$。正规方程法利用残差正交化为对称正定方程，可以按行累计数据，但使条件数平方，只适合条件较好的满列秩问题。QR 求解用正交变换保持残差长度，把目标分成可消去的部分和不可拟合的部分，满列秩时回代 $\boldsymbol{R}\hat{\boldsymbol{x}} = \boldsymbol{c}_1$，满行秩时对 $\boldsymbol{A}^{\top}$ 分解得到最小范数解。

三种 QR 实现的差别在于怎样计算正交因子。修正 Gram–Schmidt 直接算出正交基，有限精度下可能失去正交性；Householder 反射一次消去整列，选取同号符号避免相消，是稠密问题的标准做法；Givens 旋转一次消去一个元素，适合稀疏结构和逐行更新。秩亏或秩未知时，SVD 求解在奇异坐标下把目标分离成独立的标量问题，对任意形状和秩给出 $\boldsymbol{A}^{\dagger}\boldsymbol{b}$；加权问题经白化化为普通情形，齐次问题取完整右奇异基中伸缩量最小的方向。

无论用哪种方法，结果都要回到原始数据上按目标检验：精确解看残差是否为零，最小二乘解看残差是否与列空间正交，最小范数解还要看是否与零空间正交。这些检验说明算出的 $\boldsymbol{x}$ 符合目标，却不说明它离真解有多近。主元增长、条件数平方和小奇异值的放大在本章只作了算法层面的说明，结果的可信程度、数值秩的判定以及正则化留给第 14章。矩阵太大而无法分解，或只能通过矩阵与向量的乘积访问矩阵时，就需要从第 11章开始的迭代法。

第 11 章

定常迭代法

设 $\boldsymbol{A} \in \mathbb{R}^{d\times d}$ 可逆，要解 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$。第 10章的直接法先分解 $\boldsymbol{A}$ 再回代，要存储并计算分解因子。矩阵很大而稀疏时，消元会在原来的零元位置产生大量非零元（填充），因子的存储和运算都可能难以承受。

本章换一条路线。选一个容易求解、又与 $\boldsymbol{A}$ 相近的矩阵 $\boldsymbol{M}$，每轮根据当前残差，解一个以 $\boldsymbol{M}$ 为系数的方程得到修正量，再把修正量加到近似解上。每轮只需一次矩阵乘向量和一次简单求解（对角缩放或三角求解），不需要存储分解因子。这样做立即带来几个问题：这种更新从任意初值出发何时收敛到真解，收敛有多快，每轮要花多少计算，以及什么时候可以停下来。

回答收敛问题的工具来自第 8章。那里证明了：仿射迭代 $\boldsymbol{x} \mapsto \boldsymbol{T}\boldsymbol{x} + \boldsymbol{c}$ 从任意初值出发都收敛到同一个极限，当且仅当 $\boldsymbol{T}$ 的谱半径小于一；渐近的收敛速度由谱半径决定，而非正规的 $\boldsymbol{T}$ 在衰减之前还可能暂时放大误差。本章把每种方法都写成这种形式，收敛判断便归结为估计相应迭代矩阵的谱半径。三角求解采用第 10.1节的前代与回代。

第 11.1节建立各方法共用的框架：修正方程怎样得到，统一的算法流程，以及由谱半径给出的收敛判据。随后五节分别取不同的 $\boldsymbol{M}$：Richardson 迭代用标量矩阵，Jacobi 迭代用 $\boldsymbol{A}$ 的对角部分，Gauss–Seidel 迭代用下三角部分，SOR 在下三角修正中加入松弛参数，SSOR 把前向与反向两次扫掠配成对称的一轮。每节都分主要思想、算法实现与算法分析三部分，并用同一个二维例子逐轮计算，便于对照各方法读取数据的方式。

SSOR 的修正矩阵对称正定，这使它还能作为第 12章共轭梯度法的预条件。最后一节讨论停止准则：达到残差要求与只是停止计算是两回事。

记号沿用本部分的约定：精确解记作 $\boldsymbol{x}_\star$，第 k 轮近似记作 $\boldsymbol{x}_k$，残差 $\boldsymbol{r}_k = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_k$，修正量 $\boldsymbol{\delta}_k$，误差 $\boldsymbol{e}_k = \boldsymbol{x}_k - \boldsymbol{x}_\star$；向量的第 i 个分量写作 $(\boldsymbol{x}_k)_i$。

11.1 矩阵分裂与定常迭代

11.1.1 主要思想

先看一次修正需要什么。设当前近似为 $\boldsymbol{x}_k$，残差 $\boldsymbol{r}_k = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_k$ 度量各个方程还差多少。若能求出精确修正 $\boldsymbol{\delta} = \boldsymbol{x}_\star - \boldsymbol{x}_k$，一步就到达真解；但由 $\boldsymbol{A}\boldsymbol{x}_\star = \boldsymbol{b}$，它满足

$$\boldsymbol{A}\boldsymbol{\delta} = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_k = \boldsymbol{r}_k,$$

求它与解原方程一样难。

于是用一个固定、可逆且容易求解的矩阵 $\boldsymbol{M}$ 代替 $\boldsymbol{A}$，只解近似的修正方程：

$$\boldsymbol{M}\boldsymbol{\delta}_k = \boldsymbol{r}_k, \qquad \boldsymbol{x}_{k+1} = \boldsymbol{x}_k + \boldsymbol{\delta}_k.$$

$\boldsymbol{M}$ 越接近 $\boldsymbol{A}$，修正越准确，但求解也越接近原问题的难度；$\boldsymbol{M}$ 越简单，每轮越便宜，修正却越粗糙。所以 $\boldsymbol{M}$ 同时决定单步成本与每轮消除误差的程度。“容易求解”只说明每轮算得下去，并不保证迭代收敛，收敛要另行判断。因为 $\boldsymbol{M}$ 不随轮次变化，这类方法称为**定常迭代**（stationary iteration）。

把两式合并，可以看清 $\boldsymbol{M}$ 与 $\boldsymbol{A}$ 的关系。代入 $\boldsymbol{r}_k$ 得 $\boldsymbol{M}\boldsymbol{x}_{k+1} = \boldsymbol{M}\boldsymbol{x}_k + \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_k = (\boldsymbol{M} - \boldsymbol{A})\boldsymbol{x}_k + \boldsymbol{b}$。记 $\boldsymbol{N} = \boldsymbol{M} - \boldsymbol{A}$，就有**矩阵分裂**（matrix splitting）$\boldsymbol{A} = \boldsymbol{M} - \boldsymbol{N}$，更新写成

$$\boldsymbol{M}\boldsymbol{x}_{k+1} = \boldsymbol{N}\boldsymbol{x}_k + \boldsymbol{b}, \qquad \text{即} \qquad \boldsymbol{x}_{k+1} = \boldsymbol{M}^{-1}\boldsymbol{N}\boldsymbol{x}_k + \boldsymbol{M}^{-1}\boldsymbol{b}.$$

这里的 $\boldsymbol{M}^{-1}$ 只是理论表示；执行时每轮解一次 $\boldsymbol{M}\boldsymbol{\delta}_k = \boldsymbol{r}_k$，不形成逆矩阵。

误差怎样传播，由同一式读出。精确解满足 $\boldsymbol{M}\boldsymbol{x}_\star = \boldsymbol{N}\boldsymbol{x}_\star + \boldsymbol{b}$，与更新式相减得 $\boldsymbol{M}\boldsymbol{e}_{k+1} = \boldsymbol{N}\boldsymbol{e}_k$，即

$$\boldsymbol{e}_{k+1} = \boldsymbol{M}^{-1}\boldsymbol{N}\boldsymbol{e}_k = (\boldsymbol{I} - \boldsymbol{M}^{-1}\boldsymbol{A})\boldsymbol{e}_k.$$

每轮误差乘一个固定矩阵，这正是第 8章研究过的矩阵幂问题；算法分析一小节据此给出收敛判据。

后面的方法要按元素构造 $\boldsymbol{M}$，为此统一写

$$\boldsymbol{A} = \boldsymbol{D} + \boldsymbol{L} + \boldsymbol{U},$$

其中 $\boldsymbol{D}$ 是 $\boldsymbol{A}$ 的对角部分，$\boldsymbol{L}$ 与 $\boldsymbol{U}$ 分别是严格下三角与严格上三角部分，元素保留 $\boldsymbol{A}$ 中原来的符号。有些文献写作 $\boldsymbol{A} = \boldsymbol{D} - \boldsymbol{L} - \boldsymbol{U}$，那里的 $\boldsymbol{L}, \boldsymbol{U}$ 与这里差一个负号；本章只用前一种约定，各方法的公式都据此推导。凡涉及除以对角元的方法，都要求所有 $a_{i,i} \neq 0$。

11.1.2　算法实现

初始化　算法的输入为 $\boldsymbol{A}$ 和 $\boldsymbol{b}$，输出为近似解 $\boldsymbol{x}$。超参数单独列出：初值 $\boldsymbol{x}_0$，绝对容差 $\mathrm{atol} \ge 0$ 与相对容差 $\mathrm{rtol} \ge 0$，最大迭代次数 K，以及各方法自己的固定参数。若 $\boldsymbol{M}$ 需要预处理（例如保存对角元的倒数），在开始前完成。计算中保存当前解 $\boldsymbol{x}_k$、残差 $\boldsymbol{r}_k$ 和本轮修正量 $\boldsymbol{\delta}_k$。初始化时计算 $\boldsymbol{r}_0 = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_0$，并令停止阈值 $\tau = \mathrm{atol} + \mathrm{rtol}\|\boldsymbol{b}\|_2$。

停止检查　每轮开始先检查是否停止：若 $\|\boldsymbol{r}_k\|_2 \le \tau$，就以“达到容差”结束；若 $k = K$，就以“步数耗尽”结束；两种情况都取 $\boldsymbol{x} = \boldsymbol{x}_k$。初始残差已经达标时，不做任何修正就返回。若计算中出现溢出或非数，以“数值异常”结束；若残差在许多轮内几乎不再下降，可以报告“停滞”。四种结束状态要分别报告，只有第一种表示达到了所要求的残差目标，第 11.7节再解释其含义。

求修正量并更新　通过检查后，先求本轮修正量

$$\boldsymbol{M}\boldsymbol{\delta}_k = \boldsymbol{r}_k.$$

$\boldsymbol{M}$ 选得不同，这一步的算法也不同，下面各节分别给出具体公式。得到修正量后更新当前解，并按原方程重新计算残差：

$$\boldsymbol{x}_{k+1} = \boldsymbol{x}_k + \boldsymbol{\delta}_k, \qquad \boldsymbol{r}_{k+1} = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_{k+1},$$

然后把 k 加一，回到停止检查。理论上也可以用递推 $\boldsymbol{r}_{k+1} = \boldsymbol{r}_k - \boldsymbol{A}\boldsymbol{\delta}_k$ 更新残差，两者花费相同；但递推值会因舍入逐渐偏离真实残差，所以用递推的实现至少要定期按 $\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_{k+1}$ 重新计算，停止判断以重算值为准。后面各方法都沿用这套状态和终止规则，只替换求 $\boldsymbol{\delta}_k$ 的一步。

贯穿例　各方法用同一个小例子对照。下面先取对角矩阵作 $\boldsymbol{M}$，只为核对上述流程中每个量怎样得到；为什么这样选 $\boldsymbol{M}$，在第 11.3节说明。

示例 11.1　定常迭代的贯穿例　取

$$\boldsymbol{A} = \begin{bmatrix} 4 & 1 \\ 1 & 3 \end{bmatrix}, \qquad \boldsymbol{b} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \qquad \boldsymbol{x}_0 = \boldsymbol{0},$$

精确解为 $\boldsymbol{x}_\star = (1/11, 7/11)^{\top} \approx (0.0909, 0.6364)^{\top}$。取 $\boldsymbol{M} = \mathrm{diag}(4, 3)$，它就是 $\boldsymbol{A}$ 的对角部分 $\boldsymbol{D}$。每一轮按流程做三件事：由当前残差解修正方程，更新近似解，再用原矩阵重算残差。

第一轮从初始残差 $\boldsymbol{r}_0=\boldsymbol{b}=(1,2)^{\top}$ 开始。$\boldsymbol{M}$ 是对角矩阵，解 $\boldsymbol{M}\boldsymbol{\delta}_0=\boldsymbol{r}_0$ 只需逐分量相除，得 $\boldsymbol{\delta}_0=(1/4,2/3)^{\top}$，于是 $\boldsymbol{x}_1=(1/4,2/3)^{\top}$。重新乘原矩阵得 $\boldsymbol{A}\boldsymbol{x}_1=(5/3,9/4)^{\top}$，所以 $\boldsymbol{r}_1=(-2/3,-1/4)^{\top}$。

第二轮重复同样的三步：$\boldsymbol{\delta}_1=(-\tfrac{2}{3}/4,\,-\tfrac{1}{4}/3)^{\top}=(-1/6,-1/12)^{\top}$，$\boldsymbol{x}_2=(1/12,7/12)^{\top}$，重算得 $\boldsymbol{r}_2=(1/12,1/6)^{\top}$。残差范数依次约为 2.24、0.71、0.19，在下降，但没有降到零。

每一轮的修正方程都精确地解出了，$\boldsymbol{x}_2$ 却仍不是解，原因在于修正方程用 $\boldsymbol{M}$ 代替了 $\boldsymbol{A}$：“修正已算出”不等于“方程已解完”。是否完成，只能由原方程的残差判断。

11.1.3 算法分析

收敛条件 各方法是否收敛，取决于每轮把误差变成什么。令 $\boldsymbol{T}=\boldsymbol{I}-\boldsymbol{M}^{-1}\boldsymbol{A}$ 为**迭代矩阵**（iteration matrix）。下面的定理把收敛问题归结为 $\boldsymbol{T}$ 的谱半径，后面各节只需分别估计各自的 $\rho(\boldsymbol{T})$。

定理 11.2　定常迭代的收敛判据 设 $\boldsymbol{A}$ 与 $\boldsymbol{M}$ 可逆，$\boldsymbol{x}_\star$ 是 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 的解。按 $\boldsymbol{M}\boldsymbol{\delta}_k=\boldsymbol{r}_k$，$\boldsymbol{x}_{k+1}=\boldsymbol{x}_k+\boldsymbol{\delta}_k$ 迭代时，误差满足

$$\boldsymbol{e}_{k+1}=\boldsymbol{T}\boldsymbol{e}_k,\qquad \boldsymbol{e}_k=\boldsymbol{T}^{k}\boldsymbol{e}_0,$$

且迭代对任意初值 $\boldsymbol{x}_0$ 都收敛到 $\boldsymbol{x}_\star$，当且仅当 $\rho(\boldsymbol{T})<1$。

证明 由 $\boldsymbol{r}_k=\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_k=-\boldsymbol{A}\boldsymbol{e}_k$，更新式给出 $\boldsymbol{e}_{k+1}=\boldsymbol{e}_k-\boldsymbol{M}^{-1}\boldsymbol{A}\boldsymbol{e}_k=\boldsymbol{T}\boldsymbol{e}_k$，归纳得 $\boldsymbol{e}_k=\boldsymbol{T}^{k}\boldsymbol{e}_0$。更新也可写成仿射映射 $\boldsymbol{x}\mapsto\boldsymbol{T}\boldsymbol{x}+\boldsymbol{M}^{-1}\boldsymbol{b}$。因为 $\boldsymbol{I}-\boldsymbol{T}=\boldsymbol{M}^{-1}\boldsymbol{A}$ 可逆，它只有一个固定点，满足 $\boldsymbol{M}^{-1}\boldsymbol{A}\boldsymbol{x}=\boldsymbol{M}^{-1}\boldsymbol{b}$，就是 $\boldsymbol{x}_\star$。由第 8章的定理 8.11，从任意初值出发的轨迹都收敛到同一个向量当且仅当 $\rho(\boldsymbol{T})<1$，而这个共同极限只能是固定点 $\boldsymbol{x}_\star$。 ■

算法可执行与算法收敛是两个条件：$a_{i,i}\neq 0$ 只保证每轮能算下去，不保证 $\rho(\boldsymbol{T})<1$；反过来，$\rho(\boldsymbol{T})<1$ 也不保证某种逐元素公式可以执行。

收敛速度与总成本 渐近速度由 $\boldsymbol{T}$ 的谱控制：由定理 8.16，$\|\boldsymbol{T}^{k}\|^{1/k}\to\rho(\boldsymbol{T})$，误差每缩小十倍约需 $1/\log_{10}(1/\rho(\boldsymbol{T}))$ 轮。非正规的 $\boldsymbol{T}$ 还可能在衰减前暂时放大误差（第 8.4节），所以前几轮的表现不能代替渐近判断。

收缩率与单步成本是两件事。达到给定精度的总工作量约为所需轮数乘每轮成本；每轮成本包括一次求 $\boldsymbol{\delta}_k$ 和一次计算残差的矩阵乘向量。$\boldsymbol{M}$

越接近 $\boldsymbol{A}$，谱半径通常越小，但求解 $\boldsymbol{M}$ 越贵。比较不同分裂时要把两者合起来看，不能只比较谱半径或只比较单步成本。

11.2　Richardson 迭代

11.2.1　主要思想

最简单的选择是用标量矩阵代替 $\boldsymbol{A}$：取非零步长 α，令 $\boldsymbol{M}=\alpha^{-1}\boldsymbol{I}$。修正方程 $\alpha^{-1}\boldsymbol{\delta}_k=\boldsymbol{r}_k$ 直接给出 $\boldsymbol{\delta}_k=\alpha\boldsymbol{r}_k$，更新为

$$\boldsymbol{x}_{k+1}=\boldsymbol{x}_k+\alpha(\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_k).$$

这就是 Richardson 迭代：每个残差分量按同一比例转成对应分量的修正。$\boldsymbol{A}$ 只通过矩阵乘向量进入计算，方法不必读取矩阵元素。

沿残差方向修正有一个直观解释，但要说清对象。当 $\boldsymbol{A}$ 实对称正定时，$\boldsymbol{r}_k$ 是二次函数 $\phi(\boldsymbol{x})=\frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}^{\top}\boldsymbol{x}$ 在 $\boldsymbol{x}_k$ 处的负梯度，而 ϕ 的唯一极小点就是 $\boldsymbol{x}_\star$；所以 Richardson 迭代是对 ϕ 的固定步长最速下降。残差范数平方 $\|\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}\|_2^2$ 的负梯度方向是 $2\boldsymbol{A}^{\top}\boldsymbol{r}_k$，一般与 $\boldsymbol{r}_k$ 不同，不能说沿残差方向走一定使残差范数下降最快。

步长怎样取，要看误差怎样传播。此时 $\boldsymbol{T}=\boldsymbol{I}-\alpha\boldsymbol{A}$，误差递推为 $\boldsymbol{e}_{k+1}=(\boldsymbol{I}-\alpha\boldsymbol{A})\boldsymbol{e}_k$。$\boldsymbol{A}$ 实对称正定时，把 $\boldsymbol{e}_k$ 按正交特征基展开，特征值 λ_i 对应的误差系数每轮乘 $1-\alpha\lambda_i$。要求所有方向都缩小，即每个 $|1-\alpha\lambda_i|<1$，等价于 $0<\alpha\lambda_i<2$，也就是 $0<\alpha<2/\lambda_{\max}$。步长过大时，大特征值方向的倍率小于 -1，误差在该方向上正负交替地放大；所以残差没有消失并不意味着应当加大修正。

11.2.2　算法实现

每轮的内部状态沿用 $\boldsymbol{x}_k,\boldsymbol{r}_k,\boldsymbol{\delta}_k$。使用对称正定情形的收敛保证时，先按已知的谱界核对步长是否在 $(0,2/\lambda_{\max})$ 内，没有验证过的经验步长不能写成收敛条件。每轮通过开头的检查后计算

$$\boldsymbol{\delta}_k=\alpha\boldsymbol{r}_k,\qquad \boldsymbol{x}_{k+1}=\boldsymbol{x}_k+\boldsymbol{\delta}_k,\qquad \boldsymbol{q}_{k+1}=\boldsymbol{A}\boldsymbol{x}_{k+1},\qquad \boldsymbol{r}_{k+1}=\boldsymbol{b}-\boldsymbol{q}_{k+1},$$

然后按第 11.1节的条件决定停止或继续。重算的残差同时用于检查和下一轮修正，所以每轮只需一次矩阵乘向量。

示例 11.3 Richardson 迭代的前两轮 在例 11.1中取 $\alpha = 1/4$。$\boldsymbol{A}$ 的最大特征值为 $(7+\sqrt{5})/2 \approx 4.618 < 5$，所以 $2/\lambda_{\max} > 2/5 > 1/4$，这个步长在收敛区间内。

第一轮由 $\boldsymbol{r}_0 = (1,2)^{\top}$ 得 $\boldsymbol{\delta}_0 = (1/4,1/2)^{\top}$，$\boldsymbol{x}_1 = (1/4,1/2)^{\top}$；继而 $\boldsymbol{A}\boldsymbol{x}_1 = (3/2,7/4)^{\top}$，$\boldsymbol{r}_1 = (-1/2,1/4)^{\top}$。第二轮修正为 $\frac{1}{4}\boldsymbol{r}_1 = (-1/8,1/16)^{\top}$，所以 $\boldsymbol{x}_2 = (1/8,9/16)^{\top}$，$\boldsymbol{r}_2 = (-1/16,3/16)^{\top}$。

与精确解比较，误差 $\boldsymbol{e}_2 = \boldsymbol{x}_2 - \boldsymbol{x}_\star = (3/88,-13/176)^{\top}$，长度约 0.081，而残差长度约 0.198。由 $\boldsymbol{e}_k = -\boldsymbol{A}^{-1}\boldsymbol{r}_k$，误差是残差经 $\boldsymbol{A}^{-1}$ 变换后的结果，两者方向和大小都不同，是不同的数值对象。

11.2.3 算法分析

收敛条件与最优步长 当 $\boldsymbol{A}$ 实对称正定时，由定理 11.2，收敛条件和最优步长都可以从 $\boldsymbol{A}$ 的特征值直接读出。

定理 11.4 对称正定矩阵的 Richardson 迭代 设 $\boldsymbol{A}$ 实对称正定，特征值落在 $[\lambda_{\min},\lambda_{\max}]$ 中且两端取到。Richardson 迭代对所有初值收敛当且仅当 $0 < \alpha < 2/\lambda_{\max}$；最优固定步长为 $\alpha_\star = 2/(\lambda_{\min}+\lambda_{\max})$，对应的收缩因子为

$$\rho(\boldsymbol{T}) = \frac{\kappa_2(\boldsymbol{A})-1}{\kappa_2(\boldsymbol{A})+1}.$$

证明 由主要思想中的展开，$\rho(\boldsymbol{T}) = \max_i |1-\alpha\lambda_i|$，它小于一当且仅当每个 $\alpha\lambda_i \in (0,2)$，即 $0 < \alpha < 2/\lambda_{\max}$。$|1-\alpha\lambda|$ 作为 λ 的函数在区间端点取最大，所以

$$\rho(\boldsymbol{T}) = q(\alpha) = \max\{|1-\alpha\lambda_{\min}|,\ |1-\alpha\lambda_{\max}|\}.$$

α 从零增大时，$|1-\alpha\lambda_{\min}|$ 先变小，$|1-\alpha\lambda_{\max}|$ 在 $\alpha > 1/\lambda_{\max}$ 后变大；两者大小相等、符号相反时最大值最小，即 $1-\alpha\lambda_{\min} = \alpha\lambda_{\max} - 1$，解得 $\alpha_\star$。代回得 $q(\alpha_\star) = (\lambda_{\max}-\lambda_{\min})/(\lambda_{\max}+\lambda_{\min})$，再用 $\kappa_2(\boldsymbol{A}) = \lambda_{\max}/\lambda_{\min}$。 ■

一般非对称矩阵仍可使用同一更新式，但特征值可能是复数，也没有正交特征基，上面的步长区间与最优步长不再直接适用；这时要回到定理 11.2，检查 $\rho(\boldsymbol{I}-\alpha\boldsymbol{A}) < 1$。

收敛速度与代价 谱范围越宽，$\kappa_2(\boldsymbol{A})$ 越大，收缩因子越接近一，收敛越慢。实际中谱端点往往未知，步长按已知的谱界选取，例如用 $\|\boldsymbol{A}\|$ 作 $\lambda_{\max}$ 的上界。

贯穿例中 $\lambda_{\min}\approx 2.382$, $\lambda_{\max}\approx 4.618$：$\alpha=1/4$ 时 $\rho(\boldsymbol{T})=1-\lambda_{\min}/4\approx 0.40$；最优步长 $\alpha_\star=2/7$ 给出 $\rho(\boldsymbol{T})=\sqrt{5}/7\approx 0.32$。每轮的主要代价是一次矩阵乘向量，约 $2\,\mathrm{nnz}(\boldsymbol{A})$ 次运算。停止时的残差与解误差之间的关系在第 11.7节解释。

11.3　Jacobi 迭代

11.3.1　主要思想

Richardson 迭代对所有方程用同一个比例，没有利用各个方程自身的尺度。Jacobi 迭代让每个方程只修正“自己的”未知量。第 i 个方程可以写成

$$a_{i,i}x_i=b_i-\sum_{j\neq i}a_{i,j}x_j.$$

在 $a_{i,i}\neq 0$ 时可以隔离出 x_i；若暂时把其余分量冻结在已知值上，耦合的方程组就拆成了 d 个独立的标量计算。

Jacobi 迭代把右端的其余分量统一取上一轮的值：

$$(\boldsymbol{x}_{k+1})_i=\frac{b_i-\sum_{j\neq i}a_{i,j}(\boldsymbol{x}_k)_j}{a_{i,i}},\qquad i=1,\dots,d.$$

同一轮中，右端不能混入已经算出的本轮新值；混入新值得到的是第 11.4节的 Gauss–Seidel 迭代。

把分量式汇总成矩阵形式，可以找到对应的分裂。各分量式合起来是 $\boldsymbol{D}\boldsymbol{x}_{k+1}=\boldsymbol{b}-(\boldsymbol{L}+\boldsymbol{U})\boldsymbol{x}_k$；两边减去 $\boldsymbol{D}\boldsymbol{x}_k$，得 $\boldsymbol{D}(\boldsymbol{x}_{k+1}-\boldsymbol{x}_k)=\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_k$，即

$$\boldsymbol{x}_{k+1}=\boldsymbol{x}_k+\boldsymbol{D}^{-1}\boldsymbol{r}_k,\qquad \boldsymbol{M}=\boldsymbol{D}.$$

这相当于用对角部分近似 $\boldsymbol{A}$；对角元相对非对角元越大，这个近似越好。例 11.1所取的 $\boldsymbol{M}$ 正是这个分裂。

三个条件要分开看。非零对角元保证每个分量都算得出来；各分量只读取上一轮的状态，所以可以同时计算，这是并行性的来源；是否收敛则要由迭代矩阵 $\boldsymbol{T}_{\mathrm{J}}=\boldsymbol{I}-\boldsymbol{D}^{-1}\boldsymbol{A}=-\boldsymbol{D}^{-1}(\boldsymbol{L}+\boldsymbol{U})$ 的谱半径或下面的充分条件判断。

11.3.2　算法实现

逐分量修正　开始前检查所有 $a_{i,i}\neq 0$ 并保存它们的倒数。若某个对角元为零，当前的变量排列下方法不可执行；重排行列属于另一步，重排后要

重新核对条件。每轮在通过检查后，全部分量都由同一个旧状态 $\boldsymbol{x}_k, \boldsymbol{r}_k$ 计算：

$$(\delta_k)_i = \frac{(\boldsymbol{r}_k)_i}{a_{i,i}}, \qquad (\boldsymbol{x}_{k+1})_i = (\boldsymbol{x}_k)_i + (\delta_k)_i, \qquad i = 1, \dots, d.$$

直接按上面的分量式计算也可以：对每一行求 $s_i = \sum_{j \neq i} a_{i,j} (\boldsymbol{x}_k)_j$，令 $(\boldsymbol{x}_{k+1})_i = (b_i - s_i)/a_{i,i}$；稀疏实现只遍历该行的非零元素。

整体替换 右端求和只读旧向量 $\boldsymbol{x}_k$，新分量写进另一个向量，全部 d 个分量算完之前旧向量保持不变。整轮结束后计算 $\boldsymbol{r}_{k+1} = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_{k+1}$ 并检查终止，达标时返回新向量，否则交换新旧向量进入下一轮。单个分量变化很小不能代替这个全局残差检查。若算出一个分量就覆盖旧值，后面的行会读到本轮的新值，方法就不再是 Jacobi 迭代。

加权 Jacobi 加权 Jacobi 迭代只增加一个固定超参数 $\omega > 0$，把修正改成 $\delta_k = \omega \boldsymbol{D}^{-1} \boldsymbol{r}_k$，其余流程不变；$\omega = 1$ 恢复原方法。

示例 11.5 Jacobi 迭代的前两轮 在例 11.1中按分量式计算，并标明每个代入值的轮次。第一轮读取 $\boldsymbol{x}_0 = \boldsymbol{0}$：

$$(\boldsymbol{x}_1)_1 = \frac{1 - 1 \cdot 0}{4} = \frac{1}{4}, \qquad (\boldsymbol{x}_1)_2 = \frac{2 - 1 \cdot 0}{3} = \frac{2}{3};$$

第二个式子读的是旧值 0，不能代入刚得到的 $1/4$。第二轮统一读取 $\boldsymbol{x}_1 = (1/4, 2/3)^{\mathsf{T}}$：

$$(\boldsymbol{x}_2)_1 = \frac{1 - 2/3}{4} = \frac{1}{12}, \qquad (\boldsymbol{x}_2)_2 = \frac{2 - 1/4}{3} = \frac{7}{12}.$$

结果与例 11.1中按修正量计算的完全一致,残差由 $\boldsymbol{r}_1 = (-2/3, -1/4)^{\mathsf{T}}$ 变为 $\boldsymbol{r}_2 = (1/12, 1/6)^{\mathsf{T}}$。

第一轮之后两个残差分量都变成负的，说明两个修正都过了头：每个分量都在假定另一个分量不变的前提下修正，而另一个分量同时也在变。

11.3.3 算法分析

收敛条件 Jacobi 迭代矩阵 $\boldsymbol{T}_{\mathrm{J}} = -\boldsymbol{D}^{-1}(\boldsymbol{L} + \boldsymbol{U})$ 第 i 行的非对角元为 $-a_{i,j}/a_{i,i}$，对角元为零。当每行的对角元压过同一行其余元素时，这个矩阵的行和范数小于一，由此得到常用的充分条件。称 $\boldsymbol{A}$**严格行对角占优**（strictly row diagonally dominant），如果每行都有 $|a_{i,i}| > \sum_{j \neq i} |a_{i,j}|$。

定理 11.6　Jacobi 迭代的收敛条件　若 $\boldsymbol{A}$ 严格行对角占优，则

$$q = \|\boldsymbol{T}_{\mathrm{J}}\|_\infty = \max_i \frac{\sum_{j\neq i}|a_{i,j}|}{|a_{i,i}|} < 1,$$

Jacobi 迭代对所有初值收敛，且 $\|\boldsymbol{e}_k\|_\infty \le q^k \|\boldsymbol{e}_0\|_\infty$。

证明　∞-范数诱导的矩阵范数等于最大行绝对值和，$\boldsymbol{T}_{\mathrm{J}}$ 第 i 行的绝对值和正是 $\sum_{j\neq i}|a_{i,j}|/|a_{i,i}|$，对角占优使它小于一。由定理 11.2，$\boldsymbol{e}_k = \boldsymbol{T}_{\mathrm{J}}^k \boldsymbol{e}_0$，再用范数的次乘性得 $\|\boldsymbol{e}_k\|_\infty \le q^k\|\boldsymbol{e}_0\|_\infty \to 0$。 ■

贯穿例两行的比值分别为 $1/4$ 与 $1/3$，所以 $q = 1/3$。对称正定本身并不够：$\boldsymbol{A} = \boldsymbol{I} + 2\boldsymbol{1}\boldsymbol{1}^{\top} \in \mathbb{R}^{3\times 3}$ 的特征值为 $7, 1, 1$，是对称正定矩阵，而它的对角部分为 $3\boldsymbol{I}$，$\boldsymbol{T}_{\mathrm{J}} = -\frac{2}{3}(\boldsymbol{1}\boldsymbol{1}^{\top} - \boldsymbol{I})$ 沿 $\boldsymbol{1}$ 方向的特征值为 $-\frac{2}{3}(3-1) = -4/3$，在与 $\boldsymbol{1}$ 正交的方向上为 $2/3$，所以 $\rho(\boldsymbol{T}_{\mathrm{J}}) = 4/3$，迭代发散。

并行性与数值敏感度　各分量的更新互不依赖，可以并行；一轮工作量与 $\mathrm{nnz}(\boldsymbol{A})$ 同阶。单步便宜、易于并行，不等于误差衰减快：$\rho(\boldsymbol{T}_{\mathrm{J}})$ 接近一时需要很多轮。很小的对角元会把残差分量放大成很大的修正，也放大其中的舍入误差。

加权 Jacobi 的步长范围　对加权 Jacobi，设 $\boldsymbol{A}$ 实对称正定，则 $\boldsymbol{D}$ 的对角元为正，迭代矩阵 $\boldsymbol{I} - \omega\boldsymbol{D}^{-1}\boldsymbol{A}$ 与 $\boldsymbol{I} - \omega\boldsymbol{D}^{-1/2}\boldsymbol{A}\boldsymbol{D}^{-1/2}$ 相似，后者对称。按 Richardson 迭代的同样论证，收敛当且仅当

$$0 < \omega < \frac{2}{\lambda_{\max}(\boldsymbol{D}^{-1/2}\boldsymbol{A}\boldsymbol{D}^{-1/2})}.$$

原方法对应 $\omega = 1$，未必位于这个区间：在前面的三阶反例 $\boldsymbol{A} = \boldsymbol{I} + 2\boldsymbol{1}\boldsymbol{1}^{\top}$ 中，$\boldsymbol{D}^{-1/2}\boldsymbol{A}\boldsymbol{D}^{-1/2} = \boldsymbol{A}/3$，最大特征值为 $7/3$，区间为 $(0, 6/7)$。

11.4　Gauss–Seidel 迭代

11.4.1　主要思想

Jacobi 在计算后面的分量时，没有用到本轮已经算出的前面分量。Gauss–Seidel 迭代按顺序处理各行，并把本轮已经得到的分量立即代入后面的方程。仍从 $a_{i,i}x_i = b_i - \sum_{j\neq i} a_{i,j}x_j$ 出发：处理第 i 行时，$j < i$ 的分量已经

更新，取本轮的新值；$j > i$ 的分量尚未访问，取上一轮的旧值。改变的只是信息读取的时刻，原方程没有变。由此得到

$$(\boldsymbol{x}_{k+1})_i = \frac{b_i - \sum_{j<i} a_{i,j}(\boldsymbol{x}_{k+1})_j - \sum_{j>i} a_{i,j}(\boldsymbol{x}_k)_j}{a_{i,i}}, \qquad i = 1, \dots, d.$$

本轮前面的分量构成了真正的计算依赖：第 i 个分量必须等前 $i-1$ 个算完。

这个顺序对应一次下三角求解。把所有本轮新量移到左边，分量式合起来是 $(\boldsymbol{D}+\boldsymbol{L})\boldsymbol{x}_{k+1} = \boldsymbol{b} - \boldsymbol{U}\boldsymbol{x}_k$；两边减去 $(\boldsymbol{D}+\boldsymbol{L})\boldsymbol{x}_k$，得

$$(\boldsymbol{D}+\boldsymbol{L})\boldsymbol{\delta}_k = \boldsymbol{r}_k, \qquad \boldsymbol{M} = \boldsymbol{D}+\boldsymbol{L}.$$

所以每轮的修正量由第 10.1节的前代求得。逐分量写出前代，就是

$$(\boldsymbol{\delta}_k)_i = \frac{(\boldsymbol{r}_k)_i - \sum_{j<i} a_{i,j}(\boldsymbol{\delta}_k)_j}{a_{i,i}},$$

其中 $\boldsymbol{r}_k$ 是本轮开始时冻结的旧残差，求和只读同一轮已经算好的前面修正。旧残差与部分更新后的残差不能混用。

迭代矩阵为 $\boldsymbol{T}_{\mathrm{GS}} = -(\boldsymbol{D}+\boldsymbol{L})^{-1}\boldsymbol{U}$。重新排列变量会改变哪些元素落在 $\boldsymbol{L}$、哪些落在 $\boldsymbol{U}$，从而改变分裂本身和收敛速度。“用了较新的信息”只是直观理由，不能据此推出对所有矩阵都比 Jacobi 快。

11.4.2 算法实现

直接更新形式 变量顺序作为超参数固定为 $1, \dots, d$，开始前检查对角元非零。每轮通过检查后，对 $i = 1, \dots, d$ 依次计算

$$s_{\mathrm{new}} = \sum_{j<i} a_{i,j}(\boldsymbol{x}_{k+1})_j, \qquad s_{\mathrm{old}} = \sum_{j>i} a_{i,j}(\boldsymbol{x}_k)_j, \qquad (\boldsymbol{x}_{k+1})_i = \frac{b_i - s_{\mathrm{new}} - s_{\mathrm{old}}}{a_{i,i}}.$$

实现时直接在一个向量上原位覆盖即可：第 i 个位置被改写时，前面的位置已是新值，后面的位置仍是旧值。解释公式时仍要区分两者。

修正形式与检查 等价地，可以先冻结 $\boldsymbol{r}_k$，逐行前代求出整个 $\boldsymbol{\delta}_k$，最后一次性令 $\boldsymbol{x}_{k+1} = \boldsymbol{x}_k + \boldsymbol{\delta}_k$。两种写法得到同一个 $\boldsymbol{x}_{k+1}$，但不能混杂：直接更新形式不使用残差，修正形式在本轮内不修改 $\boldsymbol{x}$。一整轮完成后重算 $\boldsymbol{r}_{k+1} = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_{k+1}$ 并检查终止。

示例 11.7　Gauss–Seidel 迭代的前两轮　仍从例 11.1的 $\boldsymbol{x}_0 = \boldsymbol{0}$ 出发。第一轮先算 $(\boldsymbol{x}_1)_1 = (1-0)/4 = 1/4$，与 Jacobi 相同；随后第二行使用这个新值，$(\boldsymbol{x}_1)_2 = (2 - 1\cdot\tfrac{1}{4})/3 = 7/12$。于是 $\boldsymbol{x}_1 = (1/4,\, 7/12)^{\top}$，重算得 $\boldsymbol{r}_1 = (-7/12,\, 0)^{\top}$，$\|\boldsymbol{r}_1\|_2 \approx 0.58$。与例 11.5的 $(1/4, 2/3)^{\top}$ 相比，差别正来自第二行用了新的第一分量。

第二轮先算 $(\boldsymbol{x}_2)_1 = (1 - 7/12)/4 = 5/48$，再用它算 $(\boldsymbol{x}_2)_2 = (2 - 5/48)/3 = 91/144$。完整残差为 $\boldsymbol{r}_2 = (-7/144,\, 0)^{\top}$，长度约 0.049。

两轮的第二个残差分量都是零，因为每轮最后一次坐标修正恰好让第二个方程成立；第一个方程却因第二分量随后改变而不再成立。末行已经满足，不代表前面各行也都满足，所以停止判断必须用完整残差。

11.4.3　算法分析

收敛条件　由定理 11.2，只需说明 $\rho(\boldsymbol{T}_{\mathrm{GS}}) < 1$；下面的定理给出两类常用的充分条件。

定理 11.8　Gauss–Seidel 迭代的收敛条件　若 $\boldsymbol{A}$ 严格行对角占优，或 $\boldsymbol{A}$ 实对称正定，则 $\rho(\boldsymbol{T}_{\mathrm{GS}}) < 1$，Gauss–Seidel 迭代对所有初值收敛。

证明　先设严格行对角占优。若 $\boldsymbol{T}_{\mathrm{GS}}\boldsymbol{v} = \lambda\boldsymbol{v}, \boldsymbol{v}\neq\boldsymbol{0}, |\lambda|\geq 1$，则 $-\boldsymbol{U}\boldsymbol{v} = \lambda(\boldsymbol{D}+\boldsymbol{L})\boldsymbol{v}$。取 $|v_i|$ 最大的分量，第 i 行给出 $\lambda a_{i,i}v_i = -\lambda\sum_{j<i} a_{i,j}v_j - \sum_{j>i} a_{i,j}v_j$，两边除以 $|\lambda|$ 并取绝对值，

$$|a_{i,i}||v_i| \leq \sum_{j<i}|a_{i,j}||v_j| + \frac{1}{|\lambda|}\sum_{j>i}|a_{i,j}||v_j| \leq |v_i|\sum_{j\neq i}|a_{i,j}|,$$

与对角占优矛盾。

再设 $\boldsymbol{A}$ 实对称正定，令 $\phi(\boldsymbol{x}) = \tfrac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}^{\top}\boldsymbol{x}$，则 $\phi(\boldsymbol{x}) - \phi(\boldsymbol{x}_\star) = \tfrac{1}{2}\boldsymbol{e}^{\top}\boldsymbol{A}\boldsymbol{e}$，其中 $\boldsymbol{e} = \boldsymbol{x} - \boldsymbol{x}_\star$。沿第 i 个坐标移动 t 时，ϕ 的变化为 $-t\,r_i + \tfrac{1}{2}t^2 a_{i,i}$，其中 r_i 是移动前残差的第 i 个分量。Gauss–Seidel 取 $t = r_i/a_{i,i}$，使 ϕ 减少 $r_i^2/(2a_{i,i}) \geq 0$。若一整轮 ϕ 没有减少，则每次坐标修正时都有 $r_i = 0$，各分量都没有改变，从而本轮开始时的残差 $\boldsymbol{r}_k = -\boldsymbol{A}\boldsymbol{e}_k$ 为零，$\boldsymbol{e}_k = \boldsymbol{0}$。所以对 $\boldsymbol{e}\neq\boldsymbol{0}$ 有

$$\boldsymbol{e}^{\top}\boldsymbol{A}\boldsymbol{e} > (\boldsymbol{T}_{\mathrm{GS}}\boldsymbol{e})^{\top}\boldsymbol{A}(\boldsymbol{T}_{\mathrm{GS}}\boldsymbol{e}),$$

即实对称矩阵 $\boldsymbol{A}-\boldsymbol{T}_{\mathrm{GS}}^{\top}\boldsymbol{A}\boldsymbol{T}_{\mathrm{GS}}$ 正定。现在设 $\boldsymbol{T}_{\mathrm{GS}}\boldsymbol{v}=\lambda\boldsymbol{v}$，$\boldsymbol{v}=\boldsymbol{a}+\mathrm{i}\boldsymbol{c}\neq\boldsymbol{0}$ 可以是复向量。对实对称矩阵 $\boldsymbol{S}$，$\boldsymbol{v}^{*}\boldsymbol{S}\boldsymbol{v}=\boldsymbol{a}^{\top}\boldsymbol{S}\boldsymbol{a}+\boldsymbol{c}^{\top}\boldsymbol{S}\boldsymbol{c}$，所以正定矩阵对非零复向量的二次型仍为正。于是

$$0<\boldsymbol{v}^{*}(\boldsymbol{A}-\boldsymbol{T}_{\mathrm{GS}}^{\top}\boldsymbol{A}\boldsymbol{T}_{\mathrm{GS}})\boldsymbol{v}=\boldsymbol{v}^{*}\boldsymbol{A}\boldsymbol{v}-|\lambda|^{2}\boldsymbol{v}^{*}\boldsymbol{A}\boldsymbol{v}=(1-|\lambda|^{2})\,\boldsymbol{v}^{*}\boldsymbol{A}\boldsymbol{v},$$

而 $\boldsymbol{v}^{*}\boldsymbol{A}\boldsymbol{v}>0$，故 $|\lambda|<1$，即 $\rho(\boldsymbol{T}_{\mathrm{GS}})<1$。 ■

证明的第二部分还说明，对称正定时误差的能量范数 $\|\boldsymbol{e}\|_{\boldsymbol{A}}=(\boldsymbol{e}^{\top}\boldsymbol{A}\boldsymbol{e})^{1/2}$ 每轮严格减小。

收敛速度与代价 收敛速度取决于 $\boldsymbol{T}_{\mathrm{GS}}$ 的谱，而重新排列变量会改变迭代矩阵本身。一轮是一次三角扫掠，工作量与 $\mathrm{nnz}(\boldsymbol{A})$ 同阶，但各行之间有先后依赖，不像 Jacobi 那样直接并行。贯穿例中 $\rho(\boldsymbol{T}_{\mathrm{GS}})=1/12$，小于 Jacobi 的 $\rho(\boldsymbol{T}_{\mathrm{J}})=1/\sqrt{12}\approx0.289$。

图 11.1画出了这一差别。左图中 Gauss–Seidel 的每个半步只改一个坐标，并恰好落在对应方程的直线上，折线很快收拢到 $\boldsymbol{x}_{\star}$；Jacobi 的两个分量同时按旧值修正，在解的两侧来回跳动。右图的半对数坐标中，各方法的误差大致沿直线下降，斜率对应各自的谱半径。新值的复用带来了顺序依赖，却不保证对所有矩阵都比 Jacobi 快：有的矩阵上 Jacobi 收敛而 Gauss–Seidel 发散。

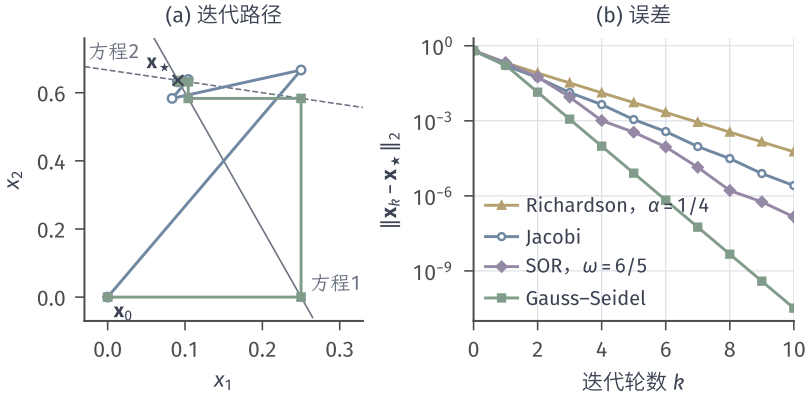


图 11.1 定常迭代在贯穿例 $\boldsymbol{A}=\begin{bmatrix}4&1\\1&3\end{bmatrix}$，$\boldsymbol{b}=(1,2)^{\top}$，$\boldsymbol{x}_0=\boldsymbol{0}$ 上的真实迭代值。左：实线与虚线分别是第一、第二个方程的解集，两者交于 $\boldsymbol{x}_{\star}=(1/11,7/11)^{\top}$；蓝色圆点为 Jacobi 前四轮的迭代点，绿色折线为 Gauss–Seidel 前三轮的逐坐标路径。右：Richardson（$\alpha=1/4$）、Jacobi、SOR（$\omega=6/5$）与 Gauss–Seidel 的误差 $\|\boldsymbol{x}_k-\boldsymbol{x}_{\star}\|_2$，纵轴取对数，渐近斜率分别对应谱半径约 0.40、0.29、0.20 与 $1/12$。

11.5 SOR 迭代

11.5.1 主要思想

Gauss–Seidel 每次坐标修正都恰好让当前方程成立，修正幅度是固定的。**逐次超松弛迭代**（successive over-relaxation，SOR）引入固定的**松弛参数**（relaxation parameter）$\omega \neq 0$，调节每次坐标修正走多远。目的是在误差沿同一方向缓慢衰减时走得更快，或在修正过冲时收敛得更稳。

具体做法分两步。处理第 i 行时，先用当前可用的数据算出 Gauss–Seidel 候选值

$$\widehat{x}_i = \frac{b_i - \sum_{j<i} a_{i,j}(\boldsymbol{x}_{k+1})_j - \sum_{j>i} a_{i,j}(\boldsymbol{x}_k)_j}{a_{i,i}},$$

再让旧值朝候选值移动 ω 倍的距离：

$$(\boldsymbol{x}_{k+1})_i = (\boldsymbol{x}_k)_i + \omega\big(\widehat{x}_i - (\boldsymbol{x}_k)_i\big) = (1-\omega)(\boldsymbol{x}_k)_i + \omega\widehat{x}_i.$$

$\omega = 1$ 就是 Gauss–Seidel；$0 < \omega < 1$ 称为欠松弛，只走一部分；$\omega > 1$ 称为过松弛，越过候选值继续走。松弛参数改变的是修正，目标方程没有变。

松弛发生在每个坐标内部：后面的行读到的是前面已经松弛后的值。先做一次完整的 Gauss–Seidel 扫掠、再把整个向量与旧向量按 ω 线性组合，一般得到的是另一种方法，不是逐坐标的 SOR。

对应的分裂可以照 Gauss–Seidel 的办法得到。把分量式乘 $a_{i,i}$ 并把本轮新量移到左边，合起来是

$$(\boldsymbol{D} + \omega\boldsymbol{L})\boldsymbol{x}_{k+1} = \omega\boldsymbol{b} + \big[(1-\omega)\boldsymbol{D} - \omega\boldsymbol{U}\big]\boldsymbol{x}_k.$$

两边减去 $(\boldsymbol{D} + \omega\boldsymbol{L})\boldsymbol{x}_k$，右边化为 $\omega(\boldsymbol{b} - \boldsymbol{D}\boldsymbol{x}_k - \boldsymbol{L}\boldsymbol{x}_k - \boldsymbol{U}\boldsymbol{x}_k) = \omega\boldsymbol{r}_k$，即

$$(\boldsymbol{D} + \omega\boldsymbol{L})\boldsymbol{\delta}_k = \omega\boldsymbol{r}_k, \qquad \boldsymbol{M} = \frac{1}{\omega}\boldsymbol{D} + \boldsymbol{L}.$$

ω 同时影响每个坐标的修正幅度与整轮的误差传播，收敛条件在算法分析中讨论。

11.5.2 算法实现

松弛前代　输入除初值、容差和上限外还有 ω，并记录变量顺序。参数是否合格与矩阵是否满足假设是两项不同的检查：对称正定情形的保证要求 $0 < \omega < 2$，同时要求 $\boldsymbol{A}$ 确实对称正定。每轮通过检查后，按既定顺序求解 $(\boldsymbol{D} + \omega\boldsymbol{L})\boldsymbol{\delta}_k = \omega\boldsymbol{r}_k$，即

$$(\boldsymbol{\delta}_k)_i = \frac{\omega}{a_{i,i}}\Big((\boldsymbol{r}_k)_i - \sum_{j<i} a_{i,j}(\boldsymbol{\delta}_k)_j\Big), \qquad i = 1, \dots, d.$$

计算当前分量时用到的，已经是前面分量松弛后的修正；$\omega = 1$ 时这一步逐项退化为 Gauss–Seidel 的前代。

直接更新与检查 等价地，可以原位逐坐标更新：对 $i = 1, \dots, d$ 保存旧分量，算出 $\hat{x}_i$，写回 $(1-\omega)(\boldsymbol{x}_k)_i + \omega\hat{x}_i$；已访问的坐标立即供后面的行读取，未访问的坐标保持旧值。一轮结束后重算残差，满足容差才以成功返回。

示例 11.9　SOR 迭代的前两轮 在例 11.1 中取 $\omega = 6/5$。第一轮中，第一行的候选值为 $1/4$，松弛后 $(\boldsymbol{x}_1)_1 = \frac{6}{5}\cdot\frac{1}{4} = 3/10$；第二行用这个松弛后的值，候选值为 $(2 - 3/10)/3 = 17/30$，于是 $(\boldsymbol{x}_1)_2 = \frac{6}{5}\cdot\frac{17}{30} = 17/25$。所以 $\boldsymbol{x}_1 = (3/10,\ 17/25)^{\mathsf{T}}$，残差 $\boldsymbol{r}_1 = (-22/25,\ -17/50)^{\mathsf{T}}$。

第二轮先算

$$(\boldsymbol{x}_2)_1 = -\frac{1}{5}\cdot\frac{3}{10} + \frac{6}{5}\cdot\frac{1 - 17/25}{4} = \frac{9}{250},$$

再用它算

$$(\boldsymbol{x}_2)_2 = -\frac{1}{5}\cdot\frac{17}{25} + \frac{6}{5}\cdot\frac{2 - 9/250}{3} = \frac{406}{625},$$

残差 $\boldsymbol{r}_2 = (129/625,\ 19/1250)^{\mathsf{T}}$。

与例 11.7 不同，第二个方程不再恰好成立，因为它的修正被放大了五分之一。若先做完整一轮 Gauss–Seidel、再按 ω 把它与旧向量组合，得到的是 $\frac{6}{5}(1/4, 7/12)^{\mathsf{T}} = (3/10, 7/10)^{\mathsf{T}}$，与 $\boldsymbol{x}_1$ 不同。

就这个例子而言，过松弛并没有带来好处：两轮的残差长度约为 0.94 与 0.21，都大于 Gauss–Seidel 的 0.58 与 0.049。有限轮的算例只用来解释计算过程；参数的优劣要由下面的谱半径判断。

11.5.3 算法分析

收敛条件 SOR 的迭代矩阵为

$$\boldsymbol{T}_\omega = \boldsymbol{I} - \omega(\boldsymbol{D} + \omega\boldsymbol{L})^{-1}\boldsymbol{A} = (\boldsymbol{D} + \omega\boldsymbol{L})^{-1}\big[(1-\omega)\boldsymbol{D} - \omega\boldsymbol{U}\big].$$

松弛参数不能随意取：它的取值范围对一般矩阵有一条必要条件，对实对称正定矩阵则恰好也是充分条件。

定理 11.10　SOR 迭代的收敛条件 设 $\boldsymbol{A}$ 的对角元全不为零。

1. 对任意这样的方阵，$\rho(\boldsymbol{T}_\omega) \geq |1 - \omega|$；所以 SOR 对所有初值收敛的必要条件是 $0 < \omega < 2$。

2. 若 $\boldsymbol{A}$ 实对称正定且 $0<\omega<2$，则 $\rho(\boldsymbol{T}_\omega)<1$，SOR 对所有初值收敛。

证明　(1) $\boldsymbol{D}+\omega\boldsymbol{L}$ 是下三角阵，行列式为 $\prod_i a_{i,i}$；$(1-\omega)\boldsymbol{D}-\omega\boldsymbol{U}$ 是上三角阵，行列式为 $(1-\omega)^d\prod_i a_{i,i}$。所以 $\det\boldsymbol{T}_\omega=(1-\omega)^d$。行列式等于全部特征值之积，其模不超过 $\rho(\boldsymbol{T}_\omega)^d$，故 $\rho(\boldsymbol{T}_\omega)\geq|1-\omega|$。若 $\omega\leq 0$ 或 $\omega\geq 2$，则 $\rho(\boldsymbol{T}_\omega)\geq 1$，由定理 11.2不能对所有初值收敛。

(2) 第 i 次坐标修正的步长是 $t=\omega r_i/a_{i,i}$，代入定理 11.8证明中的能量变化式，ϕ 减少

$$\omega\frac{r_i^2}{a_{i,i}}-\frac{\omega^2}{2}\frac{r_i^2}{a_{i,i}}=\frac{\omega(2-\omega)\,r_i^2}{2a_{i,i}}.$$

当 $0<\omega<2$ 时这是非负量，且只在 $r_i=0$ 时为零。此后的论证与该证明相同：一整轮能量不减少只能是 $\boldsymbol{e}_k=\boldsymbol{0}$，于是 $\boldsymbol{A}-\boldsymbol{T}_\omega^{\top}\boldsymbol{A}\boldsymbol{T}_\omega$ 正定，再由特征向量的二次型得 $\rho(\boldsymbol{T}_\omega)<1$。 ■

参数选择与代价　区间内收敛不等于每个参数都比 Gauss–Seidel 快。收敛速度取决于参数和变量排列：三对角等特殊结构的矩阵有由 $\rho(\boldsymbol{T}_{\mathrm{J}})$ 给出的最优参数公式，但不能普遍套用。贯穿例的 $\omega=6/5$ 就使谱半径从 Gauss–Seidel 的 $1/12$ 升到 0.2。ω 接近区间端点时，由第一部分 $\rho(\boldsymbol{T}_\omega)\geq|1-\omega|$ 接近一，收敛可能很弱。一轮成本与 Gauss–Seidel 同阶。

11.6　SSOR 迭代

11.6.1　主要思想

单向扫掠依赖变量顺序，对应的 $\boldsymbol{M}=\boldsymbol{D}/\omega+\boldsymbol{L}$ 也不对称。对实对称正定的 $\boldsymbol{A}$，**对称逐次超松弛迭代**（symmetric SOR，SSOR）把一次前向 SOR 扫掠与一次反向 SOR 扫掠配成一轮，超参数取固定的 $0<\omega<2$。下面把两次修正合并成一个修正矩阵，并推导缩放常数，使独立迭代与作为预条件的实现使用同一约定。

对称性给出 $\boldsymbol{U}=\boldsymbol{L}^{\top}$。记

$$\boldsymbol{F}=\boldsymbol{D}+\omega\boldsymbol{L},\qquad \boldsymbol{F}^{\top}=\boldsymbol{D}+\omega\boldsymbol{U}.$$

前向半步就是一次 SOR：解 $\boldsymbol{F}\boldsymbol{\delta}_{\mathrm{f}}=\omega\boldsymbol{r}_k$，令 $\boldsymbol{x}_{k+1/2}=\boldsymbol{x}_k+\boldsymbol{\delta}_{\mathrm{f}}$。反向半步按 $i=d,\dots,1$ 的顺序做 SOR，此时先访问的是下标大的分量，所以新值出现

在上三角部分，对应的方程是 $\boldsymbol{F}^{\top}\boldsymbol{\delta}_{\mathrm{b}} = \omega \boldsymbol{r}_{k+1/2}$，再令 $\boldsymbol{x}_{k+1} = \boldsymbol{x}_{k+1/2} + \boldsymbol{\delta}_{\mathrm{b}}$。右端必须是半步后的残差

$$\boldsymbol{r}_{k+1/2} = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_{k+1/2} = \boldsymbol{r}_k - \boldsymbol{A}\boldsymbol{\delta}_{\mathrm{f}},$$

第二次扫掠不能继续使用未经修正的旧残差。

把两次修正相加。由 $\boldsymbol{\delta}_{\mathrm{f}} = \omega \boldsymbol{F}^{-1}\boldsymbol{r}_k$，

$$\begin{aligned}\boldsymbol{\delta}_{\mathrm{f}} + \boldsymbol{\delta}_{\mathrm{b}} &= \omega \boldsymbol{F}^{-1}\boldsymbol{r}_k + \omega \boldsymbol{F}^{-\top}\big(\boldsymbol{r}_k - \omega \boldsymbol{A}\boldsymbol{F}^{-1}\boldsymbol{r}_k\big) \\ &= \omega \boldsymbol{F}^{-\top}\big(\boldsymbol{F}^{\top}\boldsymbol{F}^{-1} + \boldsymbol{F}\boldsymbol{F}^{-1} - \omega \boldsymbol{A}\boldsymbol{F}^{-1}\big)\boldsymbol{r}_k = \omega \boldsymbol{F}^{-\top}\big(\boldsymbol{F}^{\top} + \boldsymbol{F} - \omega \boldsymbol{A}\big)\boldsymbol{F}^{-1}\boldsymbol{r}_k,\end{aligned}$$

第二个等号在第一项前插入 $\boldsymbol{F}^{-\top}\boldsymbol{F}^{\top}$，在第二项中插入 $\boldsymbol{F}\boldsymbol{F}^{-1}$。又 $\boldsymbol{F}^{\top} + \boldsymbol{F} - \omega \boldsymbol{A} = 2\boldsymbol{D} + \omega(\boldsymbol{L} + \boldsymbol{U}) - \omega(\boldsymbol{D} + \boldsymbol{L} + \boldsymbol{U}) = (2 - \omega)\boldsymbol{D}$，所以一整轮的修正为

$$\boldsymbol{\delta}_k = \omega(2 - \omega)\, \boldsymbol{F}^{-\top}\boldsymbol{D}\boldsymbol{F}^{-1}\boldsymbol{r}_k.$$

于是 SSOR 的一轮等价于以

$$\boldsymbol{M}_{\mathrm{SSOR}} = \frac{1}{\omega(2 - \omega)}(\boldsymbol{D} + \omega \boldsymbol{L})\boldsymbol{D}^{-1}(\boldsymbol{D} + \omega \boldsymbol{U}) = \frac{1}{\omega(2 - \omega)}\boldsymbol{F}\boldsymbol{D}^{-1}\boldsymbol{F}^{\top}$$

为修正矩阵的定常迭代：$\boldsymbol{M}_{\mathrm{SSOR}}\boldsymbol{\delta}_k = \boldsymbol{r}_k$。求解的次序是先解 $\boldsymbol{F}$、再乘 $\boldsymbol{D}$、最后解 $\boldsymbol{F}^{\top}$，不必显式形成 $\boldsymbol{M}_{\mathrm{SSOR}}$ 或它的逆。

这个修正矩阵对称正定。对称性由形式 $\boldsymbol{F}\boldsymbol{D}^{-1}\boldsymbol{F}^{\top}$ 直接看出。$\boldsymbol{A}$ 正定使对角元 $a_{i,i} = \boldsymbol{e}_i^{\top}\boldsymbol{A}\boldsymbol{e}_i > 0$，所以 $\boldsymbol{D} \succ 0$；$\boldsymbol{F}$ 是对角元为正的下三角阵，可逆。于是对 $\boldsymbol{v} \neq \boldsymbol{0}$，

$$\boldsymbol{v}^{\top}\boldsymbol{M}_{\mathrm{SSOR}}\boldsymbol{v} = \frac{(\boldsymbol{F}^{\top}\boldsymbol{v})^{\top}\boldsymbol{D}^{-1}(\boldsymbol{F}^{\top}\boldsymbol{v})}{\omega(2 - \omega)} > 0,$$

这里用到 $0 < \omega < 2$ 使分母为正。注意对称正定的是修正矩阵 $\boldsymbol{M}_{\mathrm{SSOR}}$；迭代矩阵 $\boldsymbol{I} - \boldsymbol{M}_{\mathrm{SSOR}}^{-1}\boldsymbol{A}$ 一般不是对称矩阵。正是 $\boldsymbol{M}_{\mathrm{SSOR}}$ 的对称正定性，使 SSOR 除了单独迭代，还能为第 12章的共轭梯度法提供预条件。

11.6.2 算法实现

双向扫掠 内部状态除 $\boldsymbol{x}_k, \boldsymbol{r}_k$ 外，多一个半步向量 $\boldsymbol{x}_{k+1/2}$。第一步按 SOR 的分量公式完成 $i = 1, \dots, d$ 的前向扫掠，得到 $\boldsymbol{x}_{k+1/2}$。第二步反向遍历 $i = d, \dots, 1$：

$$(\boldsymbol{x}_{k+1})_i = (1 - \omega)(\boldsymbol{x}_{k+1/2})_i + \frac{\omega}{a_{i,i}}\Big(b_i - \sum_{j<i} a_{i,j}(\boldsymbol{x}_{k+1/2})_j - \sum_{j>i} a_{i,j}(\boldsymbol{x}_{k+1})_j\Big),$$

下标比 i 大的分量已在本次反向扫掠中更新，比 i 小的仍是半步值。原位覆盖同样成立。

因子求解　等价的实现直接按 $\boldsymbol{M}_{\mathrm{SSOR}}$ 的三个因子求修正量。从 $\boldsymbol{r}_k=\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_k$ 出发，依次

$$\boldsymbol{F}\boldsymbol{y}=\boldsymbol{r}_k,\qquad \boldsymbol{t}=\boldsymbol{D}\boldsymbol{y},\qquad \boldsymbol{F}^{\top}\boldsymbol{z}=\boldsymbol{t},\qquad \boldsymbol{\delta}_k=\omega(2-\omega)\boldsymbol{z},$$

其中第一步是第 10.1节的前代，第三步是回代；最后令 $\boldsymbol{x}_{k+1}=\boldsymbol{x}_k+\boldsymbol{\delta}_k$，重算 $\boldsymbol{r}_{k+1}=\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_{k+1}$ 并检查终止。由主要思想中的推导，这四步与双向扫掠的缩放完全对应。

示例 11.11　SSOR 迭代的前两轮　在例 11.1中取 $\omega=1$。按双向扫掠，前向半步就是一轮 Gauss–Seidel，$\boldsymbol{x}_{1/2}=(1/4,\,7/12)^{\top}$。反向扫掠先处理第二行，$(\boldsymbol{x}_1)_2=(2-1/4)/3=7/12$，保持不变；再处理第一行，用刚得到的第二分量，$(\boldsymbol{x}_1)_1=(1-7/12)/4=5/48$。

按因子路径核对同一轮：$\boldsymbol{F}=\left[\begin{smallmatrix}4&0\\1&3\end{smallmatrix}\right]$，解 $\boldsymbol{F}\boldsymbol{y}=\boldsymbol{b}$ 得 $\boldsymbol{y}=(1/4,7/12)^{\top}$；$\boldsymbol{t}=\boldsymbol{D}\boldsymbol{y}=(1,7/4)^{\top}$；解 $\boldsymbol{F}^{\top}\boldsymbol{z}=\boldsymbol{t}$，先得 $z_2=7/12$，再得 $z_1=(1-7/12)/4=5/48$。此时 $\omega(2-\omega)=1$，$\boldsymbol{x}_1=\boldsymbol{z}=(5/48,\,7/12)^{\top}$，与双向扫掠一致。

用原方程重算，第一轮的真实残差为 $\boldsymbol{r}_1=(0,\,7/48)^{\top}$。这次为零的是第一个分量，因为反向扫掠最后修正的是第一行。第二轮得到

$$\boldsymbol{x}_2=(53/576,\,91/144)^{\top},\qquad \boldsymbol{r}_2=(0,\,7/576)^{\top}.$$

两轮中各个三角子问题都精确解出了，残差却仍不为零。验收用的是原方程的残差，不能以子问题已经解完代替。

作为预条件　作为共轭梯度法的预条件使用时，SSOR 不更新近似解，只把外层迭代给出的残差 $\boldsymbol{r}$ 变成修正方向：执行 $\boldsymbol{F}\boldsymbol{y}=\boldsymbol{r}$、$\boldsymbol{t}=\boldsymbol{D}\boldsymbol{y}$、$\boldsymbol{F}^{\top}\boldsymbol{z}=\boldsymbol{t}$ 及缩放，返回 $\boldsymbol{M}_{\mathrm{SSOR}}^{-1}\boldsymbol{r}$，近似解由外层方法另行更新。同一次外层求解中，$\omega$ 和三角因子要保持不变，否则预条件矩阵逐轮变化，外层方法依赖的固定内积结构就不成立。具体用法见第 12.11节。

11.6.3　算法分析

收敛性　$\boldsymbol{M}_{\mathrm{SSOR}}$ 正定本身还不足以断言定常迭代收敛；还需要它在二次型意义下不小于 $\boldsymbol{A}$。展开 $\boldsymbol{F}\boldsymbol{D}^{-1}\boldsymbol{F}^{\top}=\boldsymbol{D}+\omega\boldsymbol{L}+\omega\boldsymbol{U}+\omega^2\boldsymbol{L}\boldsymbol{D}^{-1}\boldsymbol{U}$，减去 $\omega(2-\omega)\boldsymbol{A}=\omega(2-\omega)(\boldsymbol{D}+\boldsymbol{L}+\boldsymbol{U})$，整理得

$$\omega(2-\omega)(\boldsymbol{M}_{\mathrm{SSOR}}-\boldsymbol{A})=(1-\omega)^2\boldsymbol{D}-\omega(1-\omega)(\boldsymbol{L}+\boldsymbol{U})+\omega^2\boldsymbol{L}\boldsymbol{D}^{-1}\boldsymbol{U}=\boldsymbol{C}\boldsymbol{D}^{-1}\boldsymbol{C}^{\top},$$

其中 $\boldsymbol{C}=(1-\omega)\boldsymbol{D}-\omega\boldsymbol{L}$，最后一步把 $\boldsymbol{C}\boldsymbol{D}^{-1}\boldsymbol{C}^{\top}$ 展开即可核对。因为 $\boldsymbol{D}\succ 0$，$\boldsymbol{C}\boldsymbol{D}^{-1}\boldsymbol{C}^{\top}\succeq 0$，所以

$$\boldsymbol{0}\prec\boldsymbol{A}\preceq\boldsymbol{M}_{\mathrm{SSOR}}.$$

由此读出迭代矩阵的谱。$\boldsymbol{M}_{\mathrm{SSOR}}$ 对称正定，有正定平方根（第 6.2节）。令 $\boldsymbol{S}=\boldsymbol{M}_{\mathrm{SSOR}}^{-1/2}\boldsymbol{A}\boldsymbol{M}_{\mathrm{SSOR}}^{-1/2}$，它实对称。若 $\boldsymbol{S}\boldsymbol{w}=\mu\boldsymbol{w}$，$\boldsymbol{w}\neq\boldsymbol{0}$，令 $\boldsymbol{y}=\boldsymbol{M}_{\mathrm{SSOR}}^{-1/2}\boldsymbol{w}$，则

$$\mu=\frac{\boldsymbol{w}^{\top}\boldsymbol{S}\boldsymbol{w}}{\boldsymbol{w}^{\top}\boldsymbol{w}}=\frac{\boldsymbol{y}^{\top}\boldsymbol{A}\boldsymbol{y}}{\boldsymbol{y}^{\top}\boldsymbol{M}_{\mathrm{SSOR}}\boldsymbol{y}}\in(0,1].$$

迭代矩阵 $\boldsymbol{T}_{\mathrm{SSOR}}=\boldsymbol{I}-\boldsymbol{M}_{\mathrm{SSOR}}^{-1}\boldsymbol{A}=\boldsymbol{M}_{\mathrm{SSOR}}^{-1/2}(\boldsymbol{I}-\boldsymbol{S})\boldsymbol{M}_{\mathrm{SSOR}}^{1/2}$ 与实对称矩阵 $\boldsymbol{I}-\boldsymbol{S}$ 相似，特征值 $1-\mu$ 全部落在 $[0,1)$ 中，所以 $\rho(\boldsymbol{T}_{\mathrm{SSOR}})<1$。由定理 11.2，在 $\boldsymbol{A}$ 实对称正定、$0<\omega<2$ 时 SSOR 对所有初值收敛。这里 $\boldsymbol{T}_{\mathrm{SSOR}}$ 本身一般不对称，只是相似于对称矩阵，因而特征值为实数。

代价与用途　一轮含两次三角扫掠（或等价的前代、对角缩放与回代），另加一次计算残差的矩阵乘向量，工作量约为 SOR 一轮的两倍；存储只多一个与 $\boldsymbol{x}$ 同长的中间向量。比较时不能只数轮数：贯穿例中 $\omega=1$ 的 SSOR 谱半径为 $1/12$，与 Gauss–Seidel 相同，每轮却多花一倍计算。SSOR 作为独立迭代往往并不比 SOR 省；它的主要价值在于对称正定的修正矩阵：作为预条件时，每次外层迭代多付两次三角求解，换来外层共轭梯度法所需步数的减少，是否划算要按总成本比较（第 12.11节）。

11.7 收敛检验与停止准则

各方法都使用第 11.1节的终止条件：$\|\boldsymbol{r}_k\|_2\le \mathrm{atol}+\mathrm{rtol}\|\boldsymbol{b}\|_2$，或 $k=K$。前者表示达到了给定的残差要求；后者只表示不再继续计算，结果未必达到精度。两种情况下输出都只是当前的 $\boldsymbol{x}_k$，所以结束状态必须一并报告。残差用真实的 $\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_k$ 计算，而不是只依赖递推值。

几种量不能代替原方程的残差检验。修正量 $\|\boldsymbol{\delta}_k\|$ 很小，可能只说明收缩因子接近一、迭代走得很慢，而不是已经接近解。残差在很多轮内几乎不降，应作为停滞报告，而不是当作收敛。计算中出现溢出或非数，应作为数值异常报告；这通常说明迭代发散或对角元过小。

残差小也不等于解的误差小。由 $\boldsymbol{x}_\star-\boldsymbol{x}_k=\boldsymbol{A}^{-1}\boldsymbol{r}_k$，误差是残差经 $\boldsymbol{A}^{-1}$ 放大的结果，两者之间隔着问题本身的敏感性；第 14.1节再给出误差界和后向误差的解释。比较不同方法时，应在相同精度要求下比较总工作量，而不是轮数；分析中的收敛率和代价用于解释算法，不加入求解器的输出。其他用递推方式维护残差的方法，递推值会因舍入而偏离真实残差，停止前也须用 $\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_k$ 复核。

11.8　本章小结

本章回答了怎样不分解 $\boldsymbol{A}$ 而逐步求解可逆方程 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$。共同的做法是矩阵分裂 $\boldsymbol{A}=\boldsymbol{M}-\boldsymbol{N}$：每轮解一个以易解矩阵 $\boldsymbol{M}$ 为系数的修正方程 $\boldsymbol{M}\boldsymbol{\delta}_k=\boldsymbol{r}_k$，再更新近似解。误差满足 $\boldsymbol{e}_{k+1}=(\boldsymbol{I}-\boldsymbol{M}^{-1}\boldsymbol{A})\boldsymbol{e}_k$，由第 8章的矩阵幂结论，迭代对任意初值收敛当且仅当迭代矩阵的谱半径小于一，渐近速度也由谱半径决定。

五种方法的区别只在于 $\boldsymbol{M}$ 怎样近似 $\boldsymbol{A}$、数据怎样读取。Richardson 取 $\boldsymbol{M}=\alpha^{-1}\boldsymbol{I}$，只需矩阵乘向量；对称正定时收敛当且仅当 $0<\alpha<2/\lambda_{\max}$，最优步长的收缩因子为 $(\kappa_2-1)/(\kappa_2+1)$。Jacobi 取 $\boldsymbol{M}=\boldsymbol{D}$，各分量只读旧值、可以并行，严格行对角占优保证收敛，对称正定本身不保证。

Gauss–Seidel 取 $\boldsymbol{M}=\boldsymbol{D}+\boldsymbol{L}$，立即使用本轮新值，相当于一次前代；严格行对角占优或对称正定都保证收敛。SOR 取 $\boldsymbol{M}=\boldsymbol{D}/\omega+\boldsymbol{L}$，$0<\omega<2$ 对一般矩阵是必要条件，对对称正定矩阵也是充分条件；区间内不同参数的速度仍须比较。SSOR 把前向与反向 SOR 配成一轮，修正矩阵 $\boldsymbol{M}_{\mathrm{SSOR}}=\boldsymbol{F}\boldsymbol{D}^{-1}\boldsymbol{F}^{\top}/[\omega(2-\omega)]$ 对称正定且满足 $\boldsymbol{A}\preceq\boldsymbol{M}_{\mathrm{SSOR}}$，由此证明收敛，并可作为共轭梯度法的预条件。

这些结论都有边界。对角元非零只保证可执行，不保证收敛；用了新信息、加了过松弛，都不自动更快；贯穿例中 Gauss–Seidel 的谱半径为 $1/12$，$\omega=6/5$ 的 SOR 反而是 0.2。比较方法要把谱半径决定的轮数与每轮成本合起来，看达到相同精度的总工作量。

停止计算也要分清含义。只有真实残差满足 $\|\boldsymbol{r}_k\|_2\le\mathrm{atol}+\mathrm{rtol}\|\boldsymbol{b}\|_2$ 才算达到残差目标；步数耗尽、停滞或数值异常都只是停止，修正量很小也不代表接近解。即使残差达标，前向误差仍受问题条件数制约，这在第 14.1节讨论；第 12章则在逐步扩大的子空间中选择近似，以改善定常迭代受谱半径限制的收敛速度。

第 12 章

Krylov 子空间法

第 11章的定常迭代每轮按同一个规则修正近似解：算出残差 $\boldsymbol{r}_k$，解一次 $\boldsymbol{M}\boldsymbol{\delta}_k = \boldsymbol{r}_k$，加到 $\boldsymbol{x}_k$ 上。这一轮的残差用完就被丢弃，下一轮只看到新的近似。可是 $\boldsymbol{r}_0, \boldsymbol{r}_1, \ldots$ 以及它们被 $\boldsymbol{A}$ 作用后的向量都携带着关于解的信息；只用最新的一个，等于每轮放弃了此前积累的全部方向。

本章的方法把这些向量张成的子空间保留下来，每轮在逐步扩大的子空间中按某个准则重新选择近似。由此产生三个问题：怎样以数值上可靠的方式生成子空间的基；在子空间中按什么准则选解，这个准则对矩阵提出什么要求；以及怎样只用固定数量的向量完成计算，而不让存储随步数增长。

各节按矩阵结构和选解准则分工。第 12.1节建立 Krylov 子空间及其与残差多项式的对应。对称正定矩阵用共轭梯度法，最小化误差的能量范数。一般方阵先用 Arnoldi 正交化生成标准正交基，再由 GMRES 最小化原残差，代价是基的存储随步数增长。对称但不定的矩阵仍可用 MINRES 最小化原残差，对称性使 Arnoldi 退化为三项递推。非对称矩阵若要固定存储，可放弃残差最小化：BiCG 用原矩阵与转置矩阵维持双正交关系，BiCGSTAB 再用局部的残差平滑取代转置乘法。

长方或秩亏的最小二乘问题另需处理，因为残差与未知量不在同一个空间。Golub–Kahan 双对角化交替作用 $\boldsymbol{A}$ 与 $\boldsymbol{A}^{\mathsf{T}}$，在两个空间中各生成一组基；LSQR 在其中最小化原残差，LSMR 最小化正规残差。最后两节讨论所有方法共用的两件事：用预条件改善迭代面对的谱分布，以及按真实残差判断何时停止。

这些方法依赖前面几章的结论。第 9章给出正规方程、最小范数解与加权最小二乘；第 10章给出修正 Gram–Schmidt、Givens 旋转、三角回代以及 LU 与 Cholesky 的消元公式；收敛界用到第 4章的实对称谱定理；停止准则、贯穿例与 SSOR 分裂沿用第 11章。需要注意，Krylov 方法每轮的步长和组合系数都由当前向量算出，迭代不是同一个线性映射的反复作用，所以第 8章关于固定误差矩阵的谱半径判据不能直接套用；收敛性要从各方法自己的选解准则推出。

记号沿用前几章：方阵情形 $\boldsymbol{A}\in\mathbb{R}^{d\times d}$，最小二乘情形 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$；精确解记作 $\boldsymbol{x}_\star$，最小二乘解记作 $\hat{\boldsymbol{x}}$，迭代近似记作 $\boldsymbol{x}_k$，残差记作 $\boldsymbol{r}_k=\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_k$。每种方法仍分主要思想、算法实现与算法分析三部分说明；Arnoldi 正交化和 Golub–Kahan 双对角化只作为求解器内部生成基的过程，它们给出的基与小矩阵不作为输出。

12.1 Krylov 子空间

设 $\boldsymbol{A}\in\mathbb{R}^{d\times d}$。从初值 $\boldsymbol{x}_0$ 出发，先算残差 $\boldsymbol{r}_0=\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_0$，它是修正方向最自然的起点：$\boldsymbol{x}_\star-\boldsymbol{x}_0=\boldsymbol{A}^{-1}\boldsymbol{r}_0$。$\boldsymbol{A}^{-1}$ 不可直接使用，但可以反复乘以 $\boldsymbol{A}$，得到第 k 个Krylov 子空间（Krylov subspace）

$$\mathcal{K}_k(\boldsymbol{A},\boldsymbol{r}_0)=\operatorname{span}\{\boldsymbol{r}_0,\boldsymbol{A}\boldsymbol{r}_0,\dots,\boldsymbol{A}^{k-1}\boldsymbol{r}_0\},$$

不引起混淆时简写为 $\mathcal{K}_k$。Krylov 子空间法把第 k 步的候选解限制在仿射集合 $\boldsymbol{x}_0+\mathcal{K}_k$ 中。每个新向量由上一个向量再乘一次 $\boldsymbol{A}$ 得到，扩大子空间只需一次矩阵乘向量，不必形成矩阵的幂。

候选解与残差之间有一个多项式对应，后面各方法的收敛分析都从它出发。

引理 12.1　Krylov 残差多项式　记 $\mathcal{P}_k=\{p:\deg p\le k,\ p(0)=1\}$。若 $\boldsymbol{x}_k\in\boldsymbol{x}_0+\mathcal{K}_k$，则存在 $p_k\in\mathcal{P}_k$ 使

$$\boldsymbol{r}_k=\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_k=p_k(\boldsymbol{A})\boldsymbol{r}_0; \tag{12.1}$$

反之，对每个 $p_k\in\mathcal{P}_k$，都有 $\boldsymbol{x}_0+\mathcal{K}_k$ 中的一个候选，其残差为 $p_k(\boldsymbol{A})\boldsymbol{r}_0$。

证明　$\boldsymbol{x}_k-\boldsymbol{x}_0$ 是 $\boldsymbol{r}_0,\dots,\boldsymbol{A}^{k-1}\boldsymbol{r}_0$ 的线性组合，可写成 $q_{k-1}(\boldsymbol{A})\boldsymbol{r}_0$，其中 $\deg q_{k-1}\le k-1$。于是 $\boldsymbol{r}_k=\boldsymbol{r}_0-\boldsymbol{A}\,q_{k-1}(\boldsymbol{A})\boldsymbol{r}_0=p_k(\boldsymbol{A})\boldsymbol{r}_0$，$p_k(t)=1-t\,q_{k-1}(t)\in\mathcal{P}_k$。反过来，$p_k\in\mathcal{P}_k$ 时 $1-p_k(t)$ 在 $t=0$ 处为零，可写成 $t\,q_{k-1}(t)$，取 $\boldsymbol{x}=\boldsymbol{x}_0+q_{k-1}(\boldsymbol{A})\boldsymbol{r}_0$ 即可。 ■

于是选一个候选解就是选一个残差多项式。这个多项式由方法逐步选择：CG 使误差的 $\boldsymbol{A}$ 范数最小，GMRES 使原残差的长度最小，BiCG 则通过左右两组方向的配对确定近似。多项式随步数整体改变，不是某个固定更新矩阵的幂，所以收敛性要从各方法的选择准则推出，不能用固定更新矩阵的谱半径判断。

子空间随 k 嵌套增大，$\mathcal{K}_k\subseteq\mathcal{K}_{k+1}$，已有方向可以继续使用，新的一步在更大的候选集合中改进旧近似。但原始幂向量不宜直接作基。若 $\boldsymbol{A}$ 有按模严格最大的特征值，$\boldsymbol{A}^j\boldsymbol{r}_0$ 的方向随 j 增大趋向相应的特征向量，相邻向

量越来越接近平行，以它们为列的矩阵越来越病态。因此后面的方法要么对每个新向量显式正交化，要么利用矩阵结构得到有数学依据的短递推，两者都只在一组性质良好的基上工作。

精确算术下 $\mathcal{K}_k$ 的维数不超过 d；一旦 $\mathcal{K}_{k+1}=\mathcal{K}_k$，子空间不再扩张，它就是 $\boldsymbol{A}$ 的不变子空间。但某个方法能否在有限步内求得精确解，还要结合它的选解准则和前提，不能只由维数上限推出。

对长方矩阵 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$，残差 $\boldsymbol{r}_0\in\mathbb{R}^m$ 与未知量所在的 $\mathbb{R}^d$ 维数不同，$\boldsymbol{A}\boldsymbol{r}_0$ 没有意义。第 12.8节的 Golub–Kahan 双对角化取零初值，在未知量空间中生成 $\mathcal{K}_k(\boldsymbol{A}^{\top}\boldsymbol{A},\boldsymbol{A}^{\top}\boldsymbol{b})$ 的标准正交基，同时在数据空间中生成与之配对的基；计算时交替作用 $\boldsymbol{A}$ 与 $\boldsymbol{A}^{\top}$，不形成 $\boldsymbol{A}^{\top}\boldsymbol{A}$。

12.2 共轭梯度法

12.2.1 主要思想

设 $\boldsymbol{A}=\boldsymbol{A}^{\top}\succ 0$。正定性给出与问题相配的内积 $\langle \boldsymbol{u},\boldsymbol{v}\rangle_{\boldsymbol{A}}=\boldsymbol{u}^{\top}\boldsymbol{A}\boldsymbol{v}$ 及范数 $\|\boldsymbol{u}\|_{\boldsymbol{A}}=(\boldsymbol{u}^{\top}\boldsymbol{A}\boldsymbol{u})^{1/2}$，称为能量范数。误差 $\boldsymbol{x}-\boldsymbol{x}_\star$ 无法直接算出，但它的能量范数可以借一个能计算的二次函数来比较。令 $\phi(\boldsymbol{x})=\tfrac12\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}^{\top}\boldsymbol{x}$，代入 $\boldsymbol{b}=\boldsymbol{A}\boldsymbol{x}_\star$ 配方，得 $\phi(\boldsymbol{x})=\tfrac12(\boldsymbol{x}-\boldsymbol{x}_\star)^{\top}\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{x}_\star)-\tfrac12\boldsymbol{x}_\star^{\top}\boldsymbol{A}\boldsymbol{x}_\star$，即

$$\phi(\boldsymbol{x})-\phi(\boldsymbol{x}_\star)=\tfrac12\|\boldsymbol{x}-\boldsymbol{x}_\star\|_{\boldsymbol{A}}^2.$$

所以在任何候选集合中，使 ϕ 最小就是使误差的 $\boldsymbol{A}$ 范数最小。

先看沿一个方向能走多远。从当前点 $\boldsymbol{x}$ 沿方向 $\boldsymbol{p}\neq\boldsymbol{0}$ 走 α，记 $\boldsymbol{r}=\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}$，展开得

$$\phi(\boldsymbol{x}+\alpha\boldsymbol{p})=\phi(\boldsymbol{x})-\alpha\,\boldsymbol{p}^{\top}\boldsymbol{r}+\tfrac12\alpha^2\,\boldsymbol{p}^{\top}\boldsymbol{A}\boldsymbol{p}.$$

正定性使 $\boldsymbol{p}^{\top}\boldsymbol{A}\boldsymbol{p}>0$，这个一元二次式开口向上，在 $\alpha=\boldsymbol{p}^{\top}\boldsymbol{r}/(\boldsymbol{p}^{\top}\boldsymbol{A}\boldsymbol{p})$ 处取最小值。新残差 $\boldsymbol{r}-\alpha\boldsymbol{A}\boldsymbol{p}$ 与 $\boldsymbol{p}$ 的内积为 $\boldsymbol{p}^{\top}\boldsymbol{r}-\alpha\boldsymbol{p}^{\top}\boldsymbol{A}\boldsymbol{p}=0$：一维最小点处，新残差与刚用过的方向正交。

逐个方向最小化时，后一步可能破坏前一步已经达到的最优。**共轭梯度法**（conjugate gradient method，CG）让搜索方向两两关于 $\boldsymbol{A}$ 共轭，即 $\boldsymbol{p}_i^{\top}\boldsymbol{A}\boldsymbol{p}_j=0$（$i\neq j$）。这时各方向对误差 $\boldsymbol{A}$ 范数的贡献互不耦合，依次作一维最小化，就等于在全部方向张成的子空间上一次完成最小化。下面推导步长和方向系数的具体形式。

第 k 步取上一段的步长，令 $\boldsymbol{r}_{k+1}=\boldsymbol{r}_k-\alpha_k\boldsymbol{A}\boldsymbol{p}_k$，于是 $\boldsymbol{p}_k^{\top}\boldsymbol{r}_{k+1}=0$。新方向取成新残差加上一个旧方向的倍数，$\boldsymbol{p}_k=\boldsymbol{r}_k+\beta_{k-1}\boldsymbol{p}_{k-1}$；上一步已经给出 $\boldsymbol{r}_k^{\top}\boldsymbol{p}_{k-1}=0$，所以 $\boldsymbol{p}_k^{\top}\boldsymbol{r}_k=\boldsymbol{r}_k^{\top}\boldsymbol{r}_k$。步长因此可以写成

$$\alpha_k=\frac{\boldsymbol{r}_k^{\top}\boldsymbol{r}_k}{\boldsymbol{p}_k^{\top}\boldsymbol{A}\boldsymbol{p}_k},$$

分子直接复用残差长度的平方。

组合系数由共轭条件决定。要求 $\boldsymbol{p}_{k+1}=\boldsymbol{r}_{k+1}+\beta_k\boldsymbol{p}_k$ 满足 $\boldsymbol{p}_k^{\top}\boldsymbol{A}\boldsymbol{p}_{k+1}=0$，先得 $\beta_k=-\boldsymbol{p}_k^{\top}\boldsymbol{A}\boldsymbol{r}_{k+1}/(\boldsymbol{p}_k^{\top}\boldsymbol{A}\boldsymbol{p}_k)$。这个式子要多算一次内积；把残差递推改写为 $\boldsymbol{A}\boldsymbol{p}_k=(\boldsymbol{r}_k-\boldsymbol{r}_{k+1})/\alpha_k$ 代入，分子成为 $-(\boldsymbol{r}_{k+1}^{\top}\boldsymbol{r}_k-\boldsymbol{r}_{k+1}^{\top}\boldsymbol{r}_{k+1})/\alpha_k$。其中第一项为零，因为相邻残差正交：$\boldsymbol{r}_{k+1}$ 与 $\boldsymbol{p}_k$ 正交，又由上一步的共轭性，$\boldsymbol{r}_{k+1}^{\top}\boldsymbol{p}_{k-1}=\boldsymbol{r}_k^{\top}\boldsymbol{p}_{k-1}-\alpha_k\boldsymbol{p}_{k-1}^{\top}\boldsymbol{A}\boldsymbol{p}_k=0$，而 $\boldsymbol{r}_k=\boldsymbol{p}_k-\beta_{k-1}\boldsymbol{p}_{k-1}$，所以 $\boldsymbol{r}_{k+1}^{\top}\boldsymbol{r}_k=0$。分母则由步长公式写成 $\boldsymbol{r}_k^{\top}\boldsymbol{r}_k/\alpha_k$，于是

$$\beta_k=\frac{\boldsymbol{r}_{k+1}^{\top}\boldsymbol{r}_{k+1}}{\boldsymbol{r}_k^{\top}\boldsymbol{r}_k}.$$

上面的推导只显式消去了与上一个方向的耦合。定理 12.3用归纳证明，在精确算术下这已经足够：新残差与此前全部方向张成的 $\mathcal{K}_{k+1}$ 正交，新方向与全部旧方向共轭。因此不必保存历史方向，每轮只保存固定数量的向量；舍入误差会破坏这些等式，后面另作讨论。

12.2.2 算法实现

输入与初始化 输入为对称正定矩阵 $\boldsymbol{A}$ 和右端 $\boldsymbol{b}$，算法只需要计算 $\boldsymbol{A}$ 乘向量；超参数为初值 $\boldsymbol{x}_0$、绝对与相对容差 atol, rtol 及步数上限 K，输出为近似解 $\boldsymbol{x}$。停止沿用第 11.7节的公共准则：$\|\boldsymbol{r}_k\|_2\le\mathrm{atol}+\mathrm{rtol}\|\boldsymbol{b}\|_2$ 时以达到要求结束，步数达到 K 时停止计算，两种情况都输出当前近似。初始化时计算 $\boldsymbol{r}_0=\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_0$，取第一个方向 $\boldsymbol{p}_0=\boldsymbol{r}_0$ 并保存 $\boldsymbol{r}_0^{\top}\boldsymbol{r}_0$；若初值已满足准则或 $K=0$，直接输出 $\boldsymbol{x}_0$。

沿当前方向更新 第 k 轮先作本轮唯一的矩阵乘向量 $\boldsymbol{q}_k=\boldsymbol{A}\boldsymbol{p}_k$，再计算步长，并沿 $\boldsymbol{p}_k$ 更新解和残差：

$$\alpha_k=\frac{\boldsymbol{r}_k^{\top}\boldsymbol{r}_k}{\boldsymbol{p}_k^{\top}\boldsymbol{q}_k},$$

$$\boldsymbol{x}_{k+1}=\boldsymbol{x}_k+\alpha_k\boldsymbol{p}_k,\qquad \boldsymbol{r}_{k+1}=\boldsymbol{r}_k-\alpha_k\boldsymbol{q}_k.$$

分子用 $\boldsymbol{r}_k^{\top}\boldsymbol{r}_k$ 代替 $\boldsymbol{p}_k^{\top}\boldsymbol{r}_k$，两者在精确算术下相等，前者可以复用上一轮的内积。正定性保证非零方向上的分母 $\boldsymbol{p}_k^{\top}\boldsymbol{q}_k>0$。残差借 $\boldsymbol{q}_k$ 递推更新，不再另乘一次 $\boldsymbol{A}$。

停止检验与新方向 然后检验新残差。满足公共准则或 $k+1=K$ 时输出 $\boldsymbol{x}_{k+1}$；否则计算

$$\beta_k=\frac{\boldsymbol{r}_{k+1}^{\top}\boldsymbol{r}_{k+1}}{\boldsymbol{r}_k^{\top}\boldsymbol{r}_k},\qquad \boldsymbol{p}_{k+1}=\boldsymbol{r}_{k+1}+\beta_k\boldsymbol{p}_k,$$

进入下一轮。检验放在形成新方向之前，残差为零时先结束，不再计算组合系数。

实现中的检查 递推残差会因舍入偏离真实残差，所以实现中每隔若干轮、以及每次准备宣布达到要求时，都用 $\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_k$ 重算一次，再按公共准则判断。若尚未收敛却出现 $\boldsymbol{p}_k^{\top}\boldsymbol{q}_k\le 0$，说明矩阵并非对称正定，或数值状态已经严重受损；这时应报告异常并停止，不能继续沿用正定 CG 的最优性保证。

示例 12.2　CG 在贯穿例上的两步 在例 11.1上逐步执行 CG，并核对残差相互正交、方向关于 $\boldsymbol{A}$ 共轭这两条性质。取该例的 $\boldsymbol{A}$、$\boldsymbol{b}=(1,2)^{\top}$ 与 $\boldsymbol{x}_0=\boldsymbol{0}$，其中 $\boldsymbol{A}$ 的行为 $(4,1)$ 与 $(1,3)$。初始化得 $\boldsymbol{r}_0=\boldsymbol{p}_0=(1,2)^{\top}$，$\boldsymbol{r}_0^{\top}\boldsymbol{r}_0=5$。第一轮 $\boldsymbol{q}_0=\boldsymbol{A}\boldsymbol{p}_0=(6,7)^{\top}$，$\alpha_0=5/20=1/4$，于是 $\boldsymbol{x}_1=(1/4,1/2)^{\top}$，$\boldsymbol{r}_1=\boldsymbol{r}_0-\alpha_0\boldsymbol{q}_0=(-1/2,1/4)^{\top}$；再由 $\boldsymbol{r}_1^{\top}\boldsymbol{r}_1=5/16$ 得 $\beta_0=1/16$，$\boldsymbol{p}_1=\boldsymbol{r}_1+\boldsymbol{p}_0/16=(-7/16,3/8)^{\top}$。可以核对 $\boldsymbol{r}_1^{\top}\boldsymbol{r}_0=0$，$\boldsymbol{p}_1^{\top}\boldsymbol{A}\boldsymbol{p}_0=\boldsymbol{p}_1^{\top}\boldsymbol{q}_0=0$。

第二轮 $\boldsymbol{q}_1=\boldsymbol{A}\boldsymbol{p}_1=(-11/8,11/16)^{\top}$，$\boldsymbol{p}_1^{\top}\boldsymbol{q}_1=55/64$，$\alpha_1=(5/16)/(55/64)=4/11$，得 $\boldsymbol{x}_2=\boldsymbol{x}_1+\alpha_1\boldsymbol{p}_1=(1/11,7/11)^{\top}$，$\boldsymbol{r}_2=\boldsymbol{0}$。逐行代回，$4/11+7/11=1$，$1/11+21/11=2$，所以 $\boldsymbol{x}_2=\boldsymbol{x}_\star$：二维问题两步即得精确解。

作为对照，若每轮都取 $\beta_k=0$，即沿当前残差作精确一维最小化（最速下降），第一步与 CG 相同，此后却在互相垂直的方向间折返，$\boldsymbol{x}_2=(1/12,7/12)^{\top}$、$\boldsymbol{x}_3=(5/48,5/8)^{\top}$，只能逐步逼近 $\boldsymbol{x}_\star$。图 12.1把两条路径画在 ϕ 的等值线上。

12.2.3 算法分析

正确性与收敛速度 正确性归结为两组关系：残差两两正交，方向两两共轭。由它们可以推出最优性，再由残差多项式得到收敛速度。

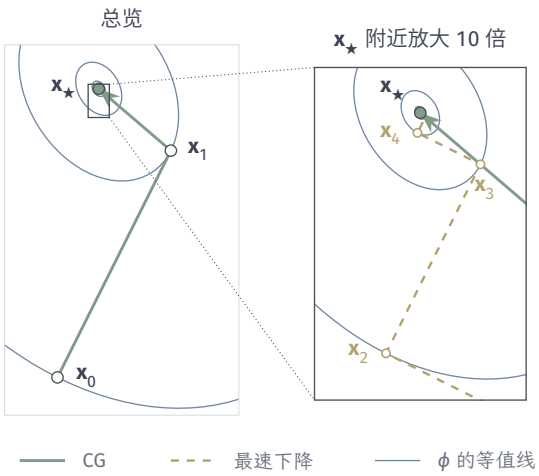


图 12.1 贯穿例上 CG 与最速下降的路径。蓝色椭圆是 $\phi(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}^{\top}\boldsymbol{x}$ 经过最速下降各迭代点的等值线，中心为 $\boldsymbol{x}_\star = (1/11, 7/11)^{\top}$。两种方法的第一步都从 $\boldsymbol{x}_0 = \boldsymbol{0}$ 走到 $\boldsymbol{x}_1 = (1/4, 1/2)^{\top}$；CG 的第二个方向与第一个方向 $\boldsymbol{A}$ 共轭，直接指向椭圆中心，最速下降则在 $\boldsymbol{x}_\star$ 附近来回折返（右图为左图小框放大 10 倍）。

定理 12.3 CG 的最优性与收敛速度 设 $\boldsymbol{A}$ 对称正定，在精确算术下按上述递推计算，且 $\boldsymbol{r}_0, \dots, \boldsymbol{r}_{k-1}$ 均非零。则 $\boldsymbol{r}_0, \dots, \boldsymbol{r}_k$ 两两正交，$\boldsymbol{p}_0, \dots, \boldsymbol{p}_{k-1}$ 两两关于 $\boldsymbol{A}$ 共轭，$\boldsymbol{x}_k$ 是 $\|\boldsymbol{x} - \boldsymbol{x}_\star\|_{\boldsymbol{A}}$ 在 $\boldsymbol{x}_0 + \mathcal{K}_k$ 上的唯一最小点，并且

$$\|\boldsymbol{x}_k - \boldsymbol{x}_\star\|_{\boldsymbol{A}} \le 2\Big(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\Big)^{k} \|\boldsymbol{x}_0 - \boldsymbol{x}_\star\|_{\boldsymbol{A}},$$

其中 $\kappa = \kappa_2(\boldsymbol{A})$。CG 至多 d 步得到精确解。

证明 先归纳证明正交与共轭关系。设 $\boldsymbol{r}_0, \dots, \boldsymbol{r}_k$ 两两正交、$\boldsymbol{p}_0, \dots, \boldsymbol{p}_k$ 两两共轭，且两组向量都张成 $\mathcal{K}_{k+1}$；$k = 0$ 时显然。由 $\boldsymbol{p}_k = \boldsymbol{r}_k + \beta_{k-1}\boldsymbol{p}_{k-1}$ 及 $\boldsymbol{r}_k \perp \boldsymbol{p}_{k-1}$，得 $\boldsymbol{p}_k^{\top}\boldsymbol{r}_k = \boldsymbol{r}_k^{\top}\boldsymbol{r}_k$，于是步长的选法给出 $\boldsymbol{p}_k^{\top}\boldsymbol{r}_{k+1} = 0$；对 $i < k$，$\boldsymbol{p}_i^{\top}\boldsymbol{r}_{k+1} = \boldsymbol{p}_i^{\top}\boldsymbol{r}_k - \alpha_k \boldsymbol{p}_i^{\top}\boldsymbol{A}\boldsymbol{p}_k = 0$。所以 $\boldsymbol{r}_{k+1} \perp \mathcal{K}_{k+1}$，特别与 $\boldsymbol{r}_0, \dots, \boldsymbol{r}_k$ 正交。对 $i < k$，$\boldsymbol{A}\boldsymbol{p}_i \in \mathcal{K}_{i+2} \subseteq \mathcal{K}_{k+1}$，故 $\boldsymbol{r}_{k+1}^{\top}\boldsymbol{A}\boldsymbol{p}_i = 0$，从而 $\boldsymbol{p}_{k+1}^{\top}\boldsymbol{A}\boldsymbol{p}_i = 0$。对 $i = k$，由 $\boldsymbol{A}\boldsymbol{p}_k = (\boldsymbol{r}_k - \boldsymbol{r}_{k+1})/\alpha_k$ 得 $\boldsymbol{r}_{k+1}^{\top}\boldsymbol{A}\boldsymbol{p}_k = -\boldsymbol{r}_{k+1}^{\top}\boldsymbol{r}_{k+1}/\alpha_k = -\beta_k\, \boldsymbol{p}_k^{\top}\boldsymbol{A}\boldsymbol{p}_k$，恰被 β_k 抵消。最后 $\boldsymbol{r}_{k+1}, \boldsymbol{p}_{k+1} \in \mathcal{K}_{k+2}$；若 $\boldsymbol{r}_{k+1} \neq \boldsymbol{0}$，正交的非零残差线性无关，两组向量都张成 $\mathcal{K}_{k+2}$。

再证最优性。记 $\boldsymbol{e}_k = \boldsymbol{x}_k - \boldsymbol{x}_\star$，则 $\boldsymbol{A}\boldsymbol{e}_k = -\boldsymbol{r}_k$，且 $\boldsymbol{r}_k \perp \mathcal{K}_k$。对任意 $\boldsymbol{z} \in \mathcal{K}_k$，

$$\|\boldsymbol{e}_k + \boldsymbol{z}\|_{\boldsymbol{A}}^2 = \|\boldsymbol{e}_k\|_{\boldsymbol{A}}^2 - 2\boldsymbol{z}^{\top}\boldsymbol{r}_k + \|\boldsymbol{z}\|_{\boldsymbol{A}}^2 = \|\boldsymbol{e}_k\|_{\boldsymbol{A}}^2 + \|\boldsymbol{z}\|_{\boldsymbol{A}}^2,$$

所以 $\boldsymbol{x}_k$ 是唯一最小点。$\mathbb{R}^d$ 中两两正交的非零向量至多 d 个，故至多 d 步出现零残差。

最后估计速度。按(12.1)的推导，$\boldsymbol{x}_0 + \mathcal{K}_k$ 中候选的误差为 $p(\boldsymbol{A})\boldsymbol{e}_0$，其中 p 的次数不超过 k 且 $p(0) = 1$。由谱定理（定理 4.21）取标准正交特征向量展开 $\boldsymbol{e}_0 = \sum_i c_i \boldsymbol{u}_i$，得 $\|p(\boldsymbol{A})\boldsymbol{e}_0\|_{\boldsymbol{A}}^2 = \sum_i \lambda_i p(\lambda_i)^2 c_i^2 \le \max_i p(\lambda_i)^2 \, \|\boldsymbol{e}_0\|_{\boldsymbol{A}}^2$。取 Chebyshev 多项式 T_k，它由 $T_k(\cos\theta) = \cos k\theta$ 确定，在 $[-1,1]$ 上 $|T_k| \le 1$；对 $x > 1$，$T_k(x) = \tfrac{1}{2}[(x + \sqrt{x^2-1})^k + (x - \sqrt{x^2-1})^k]$，因为两边满足同一递推 $T_{j+1} = 2xT_j - T_{j-1}$ 和初值。令 $\ell(t) = (\lambda_{\max} + \lambda_{\min} - 2t)/(\lambda_{\max} - \lambda_{\min})$，它把 $[\lambda_{\min}, \lambda_{\max}]$ 映到 $[-1,1]$，且 $\ell(0) = (\kappa+1)/(\kappa-1)$。取 $p(t) = T_k(\ell(t))/T_k(\ell(0))$，则在特征值上 $|p| \le 1/T_k(\ell(0))$。直接计算 $x = \ell(0)$ 时 $x + \sqrt{x^2-1} = (\sqrt{\kappa}+1)/(\sqrt{\kappa}-1)$，于是 $T_k(\ell(0)) \ge \tfrac{1}{2}\big((\sqrt{\kappa}+1)/(\sqrt{\kappa}-1)\big)^k$，即得所述界。$\kappa = 1$ 时 $\boldsymbol{A}$ 是单位阵的倍数，一步得解。 ■

这个界只依赖两端特征值，误差缩小到给定比例所需的步数约与 $\sqrt{\kappa}$ 成正比。它控制的是误差的 $\boldsymbol{A}$ 范数，欧氏残差 $\|\boldsymbol{r}_k\|_2$ 不必每步下降。

数值敏感度　浮点计算中正交与共轭关系逐步受损，定理的有限步结论不能直接移用，实际计算不承诺恰好 d 步结束；递推残差也会偏离真实残差，所以宣布达到要求前按公共准则用 $\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_k$ 复核。

计算代价　每轮核心递推需要一次 $\boldsymbol{A}$ 乘向量、两次内积和三次向量更新。除矩阵外只保存 $\boldsymbol{x}, \boldsymbol{r}, \boldsymbol{p}, \boldsymbol{q}$ 四个向量，存储不随步数增长；复核真实残差所需的矩阵乘向量另计。

12.3 Arnoldi 正交化

12.3.1 主要思想

CG 的短递推依赖对称正定结构。对一般非对称方阵，要在 Krylov 子空间中选解，先要有它的一组可靠的基。Arnoldi 正交化（Arnoldi process）不对病态的幂向量 $\boldsymbol{A}^j\boldsymbol{r}_0$ 正交化，而是每次只把最新基向量的像 $\boldsymbol{A}\boldsymbol{v}_j$ 加入当前空间：扣除它在已有基向量上的分量，剩余部分归一化后就是下一个基

向量，扣除的系数记在一个小矩阵中。它是 GMRES 的内部步骤，所得的基与小矩阵不作为方程求解的输出。

设已有标准正交向量 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_j$ 张成 $\mathcal{K}_j$。由于 $\boldsymbol{v}_j \in \mathcal{K}_j$，$\boldsymbol{w} = \boldsymbol{A}\boldsymbol{v}_j$ 属于 $\mathcal{K}_{j+1}$，可以分成已有空间内的部分与正交余项：$\boldsymbol{w} = \sum_{i \le j} h_{i,j}\boldsymbol{v}_i + \tilde{\boldsymbol{w}}$，$\tilde{\boldsymbol{w}} \perp \boldsymbol{v}_1, \dots, \boldsymbol{v}_j$。用 $\boldsymbol{v}_i$ 与两边作内积，标准正交性 $\boldsymbol{v}_i^{\top}\boldsymbol{v}_l = \delta_{il}$ 使其余项全部消失，所以投影系数只能是 $h_{i,j} = \boldsymbol{v}_i^{\top}\boldsymbol{w}$。

这些系数可以一次用原来的 $\boldsymbol{w}$ 算出，也可以按第 10.7节的修正 Gram–Schmidt 逐个扣除：依次计算 $h_{i,j} = \boldsymbol{v}_i^{\top}\boldsymbol{w}$ 并令 $\boldsymbol{w} \leftarrow \boldsymbol{w} - h_{i,j}\boldsymbol{v}_i$。精确算术下两种算法给出相同的系数，因为已经扣除的方向与后面的 $\boldsymbol{v}_i$ 正交；有限精度下后者每次都作用于当前余项，正交性保持得更好。剩余长度记为 $h_{j+1,j} = \|\tilde{\boldsymbol{w}}\|_2$，非零时令 $\boldsymbol{v}_{j+1} = \tilde{\boldsymbol{w}}/h_{j+1,j}$。

把扣除的分量加回去，第 j 轮给出 $\boldsymbol{A}\boldsymbol{v}_j = \sum_{i=1}^{j+1} h_{i,j}\boldsymbol{v}_i$。各轮的这一关系并排写成矩阵，就是 $\boldsymbol{A}\boldsymbol{V}_k = \boldsymbol{V}_{k+1}\overline{\boldsymbol{H}}_k$，其中 $\overline{\boldsymbol{H}}_k$ 的第 j 列只有前 $j+1$ 个元素可能非零。这种上 Hessenberg 形不是事先要求的，而是生成过程的结果：$\boldsymbol{A}\boldsymbol{v}_j$ 只用到前 $j+1$ 个基向量。

若某一轮余项为零，说明 $\boldsymbol{A}\boldsymbol{v}_j$ 已经落在现有空间中，Krylov 子空间不再扩张。下面的定理 12.5说明，$\boldsymbol{A}$ 非奇异时这意味着精确解已在候选集合中，因而是求解器的正常终止；不过求解器仍须用原残差确认结果。

12.3.2 算法实现

起始向量 输入沿用 GMRES 的 $\boldsymbol{A}, \boldsymbol{b}$ 和初值 $\boldsymbol{x}_0$，生成的步数由 GMRES 的重启长度及总步数上限限定。先算 $\boldsymbol{r}_0 = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_0$；若它已满足公共停止准则，就不再生成基，否则令 $\beta = \|\boldsymbol{r}_0\|_2$、$\boldsymbol{v}_1 = \boldsymbol{r}_0/\beta$。

扣除已有分量 第 j 轮先作一次矩阵乘向量 $\boldsymbol{w} = \boldsymbol{A}\boldsymbol{v}_j$，再按 $i = 1, \dots, j$ 依次计算

$$h_{i,j} = \boldsymbol{v}_i^{\top}\boldsymbol{w}, \qquad \boldsymbol{w} \leftarrow \boldsymbol{w} - h_{i,j}\boldsymbol{v}_i,$$

每个系数都用已经扣除前面分量的当前 $\boldsymbol{w}$ 计算。

再正交化 若扣除后的 $\|\boldsymbol{w}\|_2$ 远小于扣除前的 $\|\boldsymbol{A}\boldsymbol{v}_j\|_2$，说明发生了大量相消，余项可能已明显带有旧方向的成分。这时对已有基再做一遍同样的投影，得到修正量 $\delta_i = \boldsymbol{v}_i^{\top}\boldsymbol{w}$，执行 $\boldsymbol{w} \leftarrow \boldsymbol{w} - \delta_i\boldsymbol{v}_i$，并把修正量加回同一列的系数 $h_{i,j} \leftarrow h_{i,j} + \delta_i$，使分解关系保持不变。

归一化与提前终止 扣除完毕后令 $h_{j+1,j} = \|\boldsymbol{w}\|_2$，它衡量 $\boldsymbol{A}\boldsymbol{v}_j$ 中有多少是新方向。若 $h_{j+1,j}$ 为正且不低于按输入尺度设定的阈值，取 $\boldsymbol{v}_{j+1} = \boldsymbol{w}/h_{j+1,j}$

进入下一轮；若它为零或低于阈值，结束扩张，不把近零向量强行归一化，而把本轮的系数交给 GMRES 完成当前的小问题。

示例 12.4　二阶非对称矩阵上的 Arnoldi 正交化　取 $\boldsymbol{A}$ 的行为 $(3,1)$ 与 $(0,2)$，起始残差 $\boldsymbol{r}_0=(1,1)^{\top}$。起步得 $\beta=\sqrt{2}$，$\boldsymbol{v}_1=(1,1)^{\top}/\sqrt{2}$。第一轮 $\boldsymbol{A}\boldsymbol{v}_1=(4,2)^{\top}/\sqrt{2}$，$h_{1,1}=\boldsymbol{v}_1^{\top}\boldsymbol{A}\boldsymbol{v}_1=(4+2)/2=3$；扣除 $3\boldsymbol{v}_1$ 后剩下 $(1,-1)^{\top}/\sqrt{2}$，故 $h_{2,1}=1$，$\boldsymbol{v}_2=(1,-1)^{\top}/\sqrt{2}$。

第二轮 $\boldsymbol{A}\boldsymbol{v}_2=(2,-2)^{\top}/\sqrt{2}=2\boldsymbol{v}_2$，依次得到 $h_{1,2}=0$、$h_{2,2}=2$，余项为零，$h_{3,2}=0$。核对：$\boldsymbol{V}_2^{\top}\boldsymbol{V}_2=\boldsymbol{I}$，并且

$$\boldsymbol{A}\boldsymbol{V}_2=\boldsymbol{V}_2\begin{bmatrix}3 & 0\\ 1 & 2\end{bmatrix}.$$

二维空间已经用尽，$\operatorname{range}(\boldsymbol{V}_2)=\mathbb{R}^2$ 是 $\boldsymbol{A}$ 的不变子空间。这里 $h_{1,2}=0$ 只是本例的巧合；一般非对称矩阵的 $\overline{\boldsymbol{H}}_k$ 在对角线上方没有零结构。

12.3.3 算法分析

正确性　把各轮的列关系合成矩阵，就得到下面的 Arnoldi 关系，图 12.2画出了其中各矩阵的形状。

定理 12.5　Arnoldi 关系　在精确算术下执行 k 轮 Arnoldi 正交化，且前 $k-1$ 轮的 $h_{j+1,j}$ 均非零。记 $\boldsymbol{V}_k=[\boldsymbol{v}_1,\dots,\boldsymbol{v}_k]\in\mathbb{R}^{d\times k}$，$\overline{\boldsymbol{H}}_k\in\mathbb{R}^{(k+1)\times k}$ 在 $i\le j+1$ 处的元素为 $h_{i,j}$、其余为零。若 $h_{k+1,k}\neq 0$，则 $\boldsymbol{v}_1,\dots,\boldsymbol{v}_{k+1}$ 标准正交，$\boldsymbol{v}_1,\dots,\boldsymbol{v}_j$ 张成 $\mathcal{K}_j$（$j\le k+1$），并且

$$\boldsymbol{A}\boldsymbol{V}_k=\boldsymbol{V}_{k+1}\overline{\boldsymbol{H}}_k. \tag{12.2}$$

若 $h_{k+1,k}=0$，则 $\boldsymbol{v}_1,\dots,\boldsymbol{v}_k$ 标准正交且 $\boldsymbol{A}\boldsymbol{V}_k=\boldsymbol{V}_k\boldsymbol{H}_k$，其中 $\boldsymbol{H}_k$ 是 $\overline{\boldsymbol{H}}_k$ 去掉末行所得的方阵，$\mathcal{K}_k$ 在 $\boldsymbol{A}$ 下不变；$\boldsymbol{A}$ 非奇异时精确解 $\boldsymbol{x}_\star$ 属于 $\boldsymbol{x}_0+\mathcal{K}_k$。

证明　关系式(12.2)的第 j 列就是 $\boldsymbol{A}\boldsymbol{v}_j=\sum_{i\le j+1}h_{i,j}\boldsymbol{v}_i$。对正交性归纳：设 $\boldsymbol{v}_1,\dots,\boldsymbol{v}_j$ 标准正交。第 i 次扣除后 $\boldsymbol{w}\perp\boldsymbol{v}_i$，此后扣除的方向 $\boldsymbol{v}_{i+1},\dots,\boldsymbol{v}_j$ 都与 $\boldsymbol{v}_i$ 正交，不破坏这一关系，所以最终的 $\boldsymbol{w}$ 与 $\boldsymbol{v}_1,\dots,\boldsymbol{v}_j$ 都正交，归一化后得 $\boldsymbol{v}_{j+1}$。又因 $\boldsymbol{A}\boldsymbol{v}_j\in\mathcal{K}_{j+1}$，$\boldsymbol{v}_{j+1}\in\mathcal{K}_{j+1}$，$j+1$ 个标准正交向量张成维数不超过 $j+1$ 的 $\mathcal{K}_{j+1}$。若 $h_{k+1,k}=0$，第 k 列成为 $\boldsymbol{A}\boldsymbol{v}_k=\sum_{i\le k}h_{i,k}\boldsymbol{v}_i$，于是 $\boldsymbol{A}\boldsymbol{V}_k=\boldsymbol{V}_k\boldsymbol{H}_k$，$\boldsymbol{A}\mathcal{K}_k\subseteq\mathcal{K}_k$。$\boldsymbol{A}$ 非奇

异时它在有限维空间 $\mathcal{K}_k$ 上是单射，因而也是满射；$\boldsymbol{r}_0 \in \mathcal{K}_k$，故有 $\boldsymbol{z} \in \mathcal{K}_k$ 使 $\boldsymbol{A}\boldsymbol{z} = \boldsymbol{r}_0$，$\boldsymbol{x}_\star = \boldsymbol{x}_0 + \boldsymbol{z}$。 ■

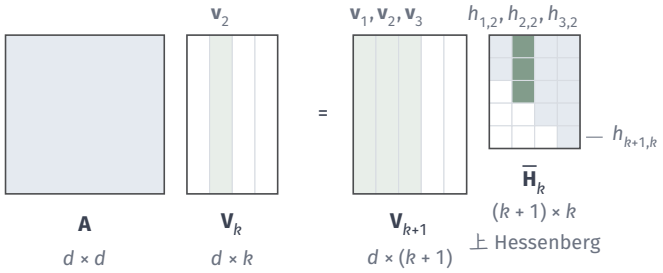


图 12.2 Arnoldi 关系 $\boldsymbol{A}\boldsymbol{V}_k = \boldsymbol{V}_{k+1}\overline{\boldsymbol{H}}_k$ 中各矩阵的形状（示意 $d = 7$、$k = 4$）。$\overline{\boldsymbol{H}}_k$ 的非零元（浅蓝）只出现在主对角线、其上方和紧邻的下次对角线上，是上 Hessenberg 矩阵，末行只剩 $h_{k+1,k}$。绿色标出第 $j = 2$ 列：$\boldsymbol{A}\boldsymbol{v}_2$ 只用到 $\boldsymbol{v}_1, \boldsymbol{v}_2, \boldsymbol{v}_3$，系数是 $\overline{\boldsymbol{H}}_k$ 第 2 列的前三个元素。

图中 $\boldsymbol{V}_{k+1}$ 只比 $\boldsymbol{V}_k$ 多一列，而 $\overline{\boldsymbol{H}}_k$ 只有 $k+1$ 行：d 维的矩阵作用被压缩成一个小矩阵，GMRES 与 MINRES 正是在这个小矩阵上求解。定理的最后一种情形说明子空间不再扩张时，精确解已在候选集合中，GMRES 在这一步得到精确解。

数值敏感度与计算代价 有限精度下基的正交性会逐渐损失，判断与补救办法沿用第 10.7节对修正 Gram–Schmidt 的讨论，必要时按上面的方式再正交化。每轮新增一次 $\boldsymbol{A}$ 乘向量。第 j 轮的投影约需 $4dj$ 次浮点运算，k 轮合计约 $2dk^2$ 次；保存 $\boldsymbol{V}_{k+1}$ 约需 $(k+1)d$ 个数。投影工作量和基的存储都随保留的向量数增长；本过程只负责生成候选空间，收敛快慢由后面的选解方法决定。

12.4 广义最小残差法

12.4.1 主要思想

广义最小残差法（generalized minimal residual method，GMRES）在当前仿射 Krylov 空间中直接使原残差最小。设当前重启周期的起点为 $\boldsymbol{x}^{(s)}$，残差为 $\boldsymbol{r}^{(s)}$，$\beta = \|\boldsymbol{r}^{(s)}\|_2$，Arnoldi 从 $\boldsymbol{v}_1 = \boldsymbol{r}^{(s)}/\beta$ 出发。写 $\boldsymbol{x} = \boldsymbol{x}^{(s)} + \boldsymbol{V}_j\boldsymbol{y}$，由 $\boldsymbol{r}^{(s)} = \beta\boldsymbol{V}_{j+1}\boldsymbol{e}_1$ 及(12.2),

$$\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x} = \boldsymbol{r}^{(s)} - \boldsymbol{A}\boldsymbol{V}_j\boldsymbol{y} = \boldsymbol{V}_{j+1}(\beta\boldsymbol{e}_1 - \overline{\boldsymbol{H}}_j\boldsymbol{y}).$$

$\boldsymbol{V}_{j+1}$ 的列标准正交，乘以它不改变长度，于是 d 维中的最小化准确地化为 $(j+1)\times j$ 的小型最小二乘问题

$$\min_{\boldsymbol{y}\in\mathbb{R}^{j}} \|\beta\boldsymbol{e}_1 - \overline{\boldsymbol{H}}_j\boldsymbol{y}\|_2 .$$

小问题用第 10.7节的 Givens 旋转化为上三角。$\overline{\boldsymbol{H}}_j$ 每列只在对角线下多一个非零元，所以设前 $j-1$ 列已化为上三角，新的第 j 列先依次经过已保存的旋转，此后只剩第 j 行的 a 和第 $j+1$ 行的 $h = h_{j+1,j}$ 两个待处理的元素。取 $\rho = \sqrt{a^2+h^2}$（实际用不会溢出的 $\operatorname{hypot}(a,h)$ 计算）、$c = a/\rho$、$s = h/\rho$，则

$$\begin{bmatrix} c & s \\ -s & c \end{bmatrix}\begin{bmatrix} a \\ h \end{bmatrix} = \begin{bmatrix} (a^2+h^2)/\rho \\ (-ha+ah)/\rho \end{bmatrix} = \begin{bmatrix} \rho \\ 0 \end{bmatrix}.$$

同一旋转也作用于小右端，前面的旋转因此可以保留下来重复使用，每增加一列只需构造一个新旋转。

全部 j 个旋转作用后，小矩阵成为上三角块 $\boldsymbol{R}_j$ 下接一行零，右端成为 $\boldsymbol{g}$，正交变换不改变长度，所以

$$\|\beta\boldsymbol{e}_1 - \overline{\boldsymbol{H}}_j\boldsymbol{y}\|_2^2 = \|(g_1,\dots,g_j)^{\mathsf{T}} - \boldsymbol{R}_j\boldsymbol{y}\|_2^2 + g_{j+1}^2 .$$

第二项与 $\boldsymbol{y}$ 无关，第一项在回代解 $\boldsymbol{R}_j\boldsymbol{y} = (g_1,\dots,g_j)^{\mathsf{T}}$ 时为零。因此最小残差就是 $|g_{j+1}|$，不必形成近似解即可读出；需要输出时再由 $\boldsymbol{x} = \boldsymbol{x}^{(s)} + \boldsymbol{V}_j\boldsymbol{y}$ 还原原变量。

完整保存基时存储随步数增长，实际常用重启：每个周期最多走 m 步，先用本周期的系数更新 $\boldsymbol{x}$，重算真实残差，再从这个残差重新生成基。丢弃旧基改变的是此后允许搜索的空间；每个周期内的残差仍最小，但这只是在本周期子空间上的最优，不能说成累计全部历史空间上的最优。

12.4.2 算法实现

输入与初始化 输入为非奇异方阵 $\boldsymbol{A}$ 与 $\boldsymbol{b}$；超参数为 $\boldsymbol{x}_0$, atol, rtol, K 和重启长度 m（$1 \le m \le d$），输出为 $\boldsymbol{x}$。初始化时令 $\boldsymbol{x}^{(s)} = \boldsymbol{x}_0$，计算 $\boldsymbol{r}^{(s)} = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}^{(s)}$；若公共停止准则已满足，直接输出，不再归一化。否则令 $\beta = \|\boldsymbol{r}^{(s)}\|_2$、$\boldsymbol{v}_1 = \boldsymbol{r}^{(s)}/\beta$，并把小问题的右端置为 $\boldsymbol{g} = (\beta, 0, \dots, 0)^{\mathsf{T}}$。

Arnoldi 扩展 每个内步 j 先按第 12.3节作一轮 Arnoldi，扩充所存的基，并得到 $\overline{\boldsymbol{H}}_j$ 的新列 $(h_{1,j},\dots,h_{j+1,j})^{\mathsf{T}}$。

旋转更新残差 然后用 Givens 旋转更新残差估计。新列先依次经过已保存的旋转 $\boldsymbol{G}_1,\dots,\boldsymbol{G}_{j-1}$，整个矩阵才对应同一个正交变换。此后新列只剩第 j 行的 a 和第 $j+1$ 行的 $h=h_{j+1,j}$ 两个待处理的元素，按主要思想中的公式令

$$\rho_j=\sqrt{a^2+h^2},\qquad c_j=a/\rho_j,\qquad s_j=h/\rho_j,$$

$$\boldsymbol{G}_j=\begin{bmatrix} c_j & s_j \\ -s_j & c_j \end{bmatrix},$$

$\boldsymbol{G}_j$ 作用于第 $j,j+1$ 行，把 $(a,h)^{\top}$ 变为 $(\rho_j,0)^{\top}$。同一旋转作用于右端，把 $(g_j,0)^{\top}$ 变为 $(c_jg_j,-s_jg_j)^{\top}$，即 $g_j\leftarrow c_jg_j$、$g_{j+1}=-s_jg_j$，前面已确定的分量不变。旋转后前 j 行构成上三角矩阵 $\boldsymbol{R}_j$，小问题的最小残差就是 $|g_{j+1}|$。

回代、恢复解与重启 当 $|g_{j+1}|$ 满足阈值、Arnoldi 不再生成新方向、本周期已达 m 步或总步数达到 K 时，结束内步，用回代解 $\boldsymbol{R}_j\boldsymbol{y}=(g_1,\dots,g_j)^{\top}$，并恢复 $\boldsymbol{x}=\boldsymbol{x}^{(s)}+\boldsymbol{V}_j\boldsymbol{y}$。再用原矩阵计算 $\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}$，按公共准则复核：满足阈值或已达总步数上限就输出 $\boldsymbol{x}$；否则以该 $\boldsymbol{x}$ 为新周期的起点 $\boldsymbol{x}^{(s)}$，从它的残差重新生成基。若几个周期后真实残差几乎不再下降，应报告停滞，而不是继续无限重启。

Arnoldi 给出 $h_{j+1,j}=0$ 时，$s_j=0$ 且 $g_{j+1}=0$，先完成小问题，不再用该系数作除法。回代中若出现零主元，说明小问题秩亏，要先检查 $\boldsymbol{A}$ 是否奇异、小问题是否相容，不能直接相除。

示例 12.6　GMRES 在贯穿例上的两步 仍取例 11.1的 $\boldsymbol{A},\boldsymbol{b}$ 与 $\boldsymbol{x}_0=\boldsymbol{0}$，$m=2$。初始化得 $\beta=\sqrt{5}$，$\boldsymbol{v}_1=(1,2)^{\top}/\sqrt{5}$，$\boldsymbol{g}=(\sqrt{5},0)^{\top}$。第一个内步 $\boldsymbol{A}\boldsymbol{v}_1=(6,7)^{\top}/\sqrt{5}$，扣除得 $h_{1,1}=4$、$\boldsymbol{w}=(2,-1)^{\top}/\sqrt{5}$，于是 $h_{2,1}=1$，$\boldsymbol{v}_2=(2,-1)^{\top}/\sqrt{5}$。旋转取 $\rho_1=\sqrt{17}$、$c_1=4/\sqrt{17}$、$s_1=1/\sqrt{17}$，右端变为 $\boldsymbol{g}=(4\sqrt{5},-\sqrt{5})^{\top}/\sqrt{17}$，残差估计 $|g_2|=\sqrt{5/17}\approx 0.542$。

若在此停止，回代得 $y_1=g_1/\rho_1=4\sqrt{5}/17$，$\boldsymbol{x}_1=y_1\boldsymbol{v}_1=(4/17,8/17)^{\top}$；复核 $\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_1=(-7,6)^{\top}/17$，长度正是 $\sqrt{5/17}$，小于 CG 第一步的残差长度 $\sqrt{5}/4\approx 0.559$。

第二个内步 $\boldsymbol{A}\boldsymbol{v}_2=(7,-1)^{\top}/\sqrt{5}$，扣除得 $h_{1,2}=1$、$h_{2,2}=3$，剩余向量为零，$h_{3,2}=0$，二维空间已经用尽。新列 $(1,3,0)^{\top}$ 先经 $\boldsymbol{G}_1$ 变为 $(7,11,0)^{\top}/\sqrt{17}$，新旋转 $c_2=1$、$s_2=0$，$g_3=0$。回代求解

$$\boldsymbol{R}_2\boldsymbol{y}=\frac{1}{\sqrt{17}}\begin{bmatrix}17 & 7\\ 0 & 11\end{bmatrix}\boldsymbol{y}=\frac{\sqrt{5}}{\sqrt{17}}\begin{bmatrix}4\\ -1\end{bmatrix},$$

得 $y_2=-\sqrt{5}/11$、$y_1=3\sqrt{5}/11$，于是恢复出 $\boldsymbol{x}_2=y_1\boldsymbol{v}_1+y_2\boldsymbol{v}_2=(1/11,7/11)^{\top}$，正是 $\boldsymbol{x}_\star$。

贯穿例的矩阵是对称的。下面换用例 12.4的非对称矩阵，逐步追踪旋转后的右端与原变量。

示例 12.7　非对称矩阵上的 GMRES　取例 12.4的 $\boldsymbol{A}$（行为 $(3,1)$ 与 $(0,2)$），$\boldsymbol{b}=(1,1)^{\top}$，$\boldsymbol{x}_0=\boldsymbol{0}$，$m=2$。于是 $\boldsymbol{r}_0=\boldsymbol{b}$，Arnoldi 的结果就是该例：$\beta=\sqrt{2}$，$\overline{\boldsymbol{H}}$ 的第一列为 $(3,1)^{\top}$。第一个旋转取 $\rho_1=\sqrt{10}$、$c_1=3/\sqrt{10}$、$s_1=1/\sqrt{10}$，把右端 $(\sqrt{2},0)^{\top}$ 转为 $(3/\sqrt{5},-1/\sqrt{5})^{\top}$。回代得 $y_1=(3/\sqrt{5})/\sqrt{10}=3\sqrt{2}/10$，故 $\boldsymbol{x}_1=y_1\boldsymbol{v}_1=(3/10,3/10)^{\top}$。直接计算 $\boldsymbol{r}_1=\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_1=(-1/5,2/5)^{\top}$，长度 $1/\sqrt{5}$，与旋转后右端的末分量 $|g_2|$ 相同。

第二个内步的新列是 $(0,2,0)^{\top}$，先经 $\boldsymbol{G}_1$ 变为 $(2/\sqrt{10},6/\sqrt{10},0)^{\top}$；由于 $h_{3,2}=0$，新旋转为 $c_2=1$、$s_2=0$，$g_3=0$。回代 $\boldsymbol{R}_2\boldsymbol{y}=(3/\sqrt{5},-1/\sqrt{5})^{\top}$ 得 $y_2=-\sqrt{2}/6$、$y_1=\sqrt{2}/3$；也可以直接解 $\boldsymbol{H}_2\boldsymbol{y}=\beta\boldsymbol{e}_1$，即 $3y_1=\sqrt{2}$、$y_1+2y_2=0$，得到同一组系数。恢复出

$$\boldsymbol{x}_2=\frac{\sqrt{2}}{3}\cdot\frac{(1,1)^{\top}}{\sqrt{2}}-\frac{\sqrt{2}}{6}\cdot\frac{(1,-1)^{\top}}{\sqrt{2}}=\Big(\frac{1}{6},\frac{1}{2}\Big)^{\top},$$

代回得 $\boldsymbol{A}\boldsymbol{x}_2=(1/2+1/2,\,1)^{\top}=\boldsymbol{b}$，原残差为零。

12.4.3 算法分析

正确性　下面的定理针对不重启的完整 GMRES，即 $m=d$ 的情形。

定理 12.8　GMRES 的最小残差性　设 $\boldsymbol{A}$ 非奇异，在精确算术下执行完整 GMRES 的第 k 步，记 $\boldsymbol{r}_k=\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_k$。则 $\boldsymbol{x}_k$ 是 $\boldsymbol{x}_0+\mathcal{K}_k$ 中残差长度的唯一最小点，$\|\boldsymbol{r}_k\|_2=|g_{k+1}|$，它等于上一步的残差长度乘以 $|s_k|\le 1$，因而随 k 不增；GMRES 至多 d 步得到精确解。若 $\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$ 可对角化（$\boldsymbol{X},\boldsymbol{\Lambda}$ 可以是复矩阵），还有

$$\|\boldsymbol{r}_k\|_2\le\kappa_2(\boldsymbol{X})\min_{p\in\mathcal{P}_k}\max_{\lambda\in\sigma(\boldsymbol{A})}|p(\lambda)|\,\|\boldsymbol{r}_0\|_2,$$

其中 $\mathcal{P}_k$ 同引理 12.1。

证明　Arnoldi 尚未停止时 $\boldsymbol{V}_k$ 满列秩，$\boldsymbol{A}$ 非奇异，所以 $\boldsymbol{A}\boldsymbol{V}_k=\boldsymbol{V}_{k+1}\overline{\boldsymbol{H}}_k$ 满列秩，$\overline{\boldsymbol{H}}_k$ 也满列秩。映射 $\boldsymbol{y}\mapsto\boldsymbol{x}_0+\boldsymbol{V}_k\boldsymbol{y}$ 是 $\mathbb{R}^k$ 到 $\boldsymbol{x}_0+\mathcal{K}_k$ 的双射，且由主要思想中的推导，两边的残差长度相等，所以两个最

小化问题的解一一对应。记 k 个旋转之积为 $\boldsymbol{\Omega}_k$，它是正交矩阵，满足 $\boldsymbol{\Omega}_k \overline{\boldsymbol{H}}_k = \begin{bmatrix} \boldsymbol{R}_k \\ \boldsymbol{0}^{\top} \end{bmatrix}$、$\boldsymbol{\Omega}_k \beta \boldsymbol{e}_1 = \boldsymbol{g}$，故

$$\|\beta \boldsymbol{e}_1 - \overline{\boldsymbol{H}}_k \boldsymbol{y}\|_2^2 = \|(g_1, \dots, g_k)^{\top} - \boldsymbol{R}_k \boldsymbol{y}\|_2^2 + g_{k+1}^2.$$

$\boldsymbol{R}_k$ 与 $\overline{\boldsymbol{H}}_k$ 秩相同，可逆，回代所得的 $\boldsymbol{y}$ 使第一项为零，且是唯一使之为零的点，最小值为 $|g_{k+1}|$。第 k 个旋转把上一步的 g_k 变为 $c_k g_k$ 与 $-s_k g_k$，所以 $|g_{k+1}| = |s_k|\,|g_k|$，其中 $|g_k|$ 是旋转前的值，即上一步的残差长度。若 $h_{k+1,k} = 0$，则 $\boldsymbol{A}\boldsymbol{V}_k = \boldsymbol{V}_k \boldsymbol{H}_k$，$\boldsymbol{H}_k$ 可逆，取 $\boldsymbol{y} = \beta \boldsymbol{H}_k^{-1} \boldsymbol{e}_1$ 即得零残差；子空间维数不超过 d，所以至多 d 步出现这一情形或零残差。最后，由引理 12.1，$\|\boldsymbol{r}_k\|_2 = \min_{p \in \mathcal{P}_k} \|p(\boldsymbol{A})\boldsymbol{r}_0\|_2$；而 $p(\boldsymbol{A}) = \boldsymbol{X} p(\boldsymbol{\Lambda}) \boldsymbol{X}^{-1}$，对角矩阵 $p(\boldsymbol{\Lambda})$ 的谱范数是 $\max_{\lambda \in \sigma(\boldsymbol{A})} |p(\lambda)|$，乘上 $\|\boldsymbol{X}\|_2 \|\boldsymbol{X}^{-1}\|_2 = \kappa_2(\boldsymbol{X})$ 即得所述界。 ■

收敛速度 定理中的界把收敛问题化为多项式逼近：要找在原点取值 1、在全部特征值上都很小的低次多项式。非正规矩阵的 $\kappa_2(\boldsymbol{X})$ 可能很大，界因此变弱，只看特征值是否集中不能判断收敛快慢。

重启与数值敏感度 重启的 GMRES(m) 丢弃了历史空间，最优性只在一个周期内成立，可能停滞，也不再有 d 步得到精确解的保证。浮点计算中基不再精确正交，$|g_{j+1}|$ 与真实残差会偏离，这就是每个周期结束时用 $\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}$ 复核的原因。

计算代价 每个内步需要一次 $\boldsymbol{A}$ 乘向量。完整 GMRES 执行 k 步时，正交化共约 $2dk^2$ 次浮点运算，基的存储约 kd 个数，都随步数增长；GMRES(m) 把历史基限制在一个周期内，每周期至多约 $2dm^2$ 次运算，存储约 $(m+1)d$ 个数，与总步数无关。

12.5 最小残差法

12.5.1 主要思想

若 $\boldsymbol{A}$ 对称，Arnoldi 的投影系数大多为零。对 $i < j-1$，$h_{i,j} = \boldsymbol{v}_i^{\top} \boldsymbol{A} \boldsymbol{v}_j = \boldsymbol{v}_j^{\top} (\boldsymbol{A}\boldsymbol{v}_i)$，而 $\boldsymbol{A}\boldsymbol{v}_i$ 只含 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_{i+1}$ 的分量，它们都与 $\boldsymbol{v}_j$ 正交，所以 $h_{i,j} = 0$。剩下的 $h_{j-1,j}$ 由对称性等于上一轮已算出的 $h_{j,j-1}$。记 $\gamma_j = h_{j+1,j}$、$a_j = h_{j,j}$，并约定 $\boldsymbol{v}_0 = \boldsymbol{0}$，Arnoldi 就退化为Lanczos 三项递推（Lanczos recurrence）：

$$\boldsymbol{w} = \boldsymbol{A}\boldsymbol{v}_j - \gamma_{j-1}\boldsymbol{v}_{j-1}, \qquad a_j = \boldsymbol{v}_j^{\top}\boldsymbol{w}, \qquad \boldsymbol{w} \leftarrow \boldsymbol{w} - a_j \boldsymbol{v}_j, \qquad \gamma_j = \|\boldsymbol{w}\|_2,$$

每轮只需扣除两个方向。

把各轮汇总，得到 $\boldsymbol{A}\boldsymbol{V}_k = \boldsymbol{V}_{k+1}\overline{\boldsymbol{T}}_k$，其中 $\overline{\boldsymbol{T}}_k$ 是对角元为 a_j、两条副对角元为 γ_j 的三对角矩阵，再在下方增加一行 $\gamma_k \boldsymbol{e}_k^{\top}$。与 GMRES 相同的推导把 $\boldsymbol{x} = \boldsymbol{x}_0 + \boldsymbol{V}_k \boldsymbol{y}$ 的残差化为 $\|\beta \boldsymbol{e}_1 - \overline{\boldsymbol{T}}_k \boldsymbol{y}\|_2$。**最小残差法**（minimal residual method，MINRES）就在这个小问题上最小化欧氏残差。它不需要能量范数，所以不要求正定：对称不定时 $\boldsymbol{u}^{\top}\boldsymbol{A}\boldsymbol{u}$ 可以为负，CG 的目标不再是范数，而残差长度始终有意义。

小问题的三角化也只涉及固定带宽。$\overline{\boldsymbol{T}}_k$ 的第 j 列只在第 $j-1, j, j+1$ 行非零，用 Givens 旋转消去次对角元时，前两个旧旋转会在第 $j-2$ 行产生一个新的非零元，因此所得上三角因子 $\boldsymbol{R}_k$ 每列至多有三个非零元，记第 j 列为 $\epsilon_j, \delta_j, \rho_j$，分别位于第 $j-2, j-1, j$ 行。

解的更新同样可以只用短递推。定义方向矩阵 $\boldsymbol{D}_k = [\boldsymbol{d}_1, \dots, \boldsymbol{d}_k]$ 满足 $\boldsymbol{D}_k \boldsymbol{R}_k = \boldsymbol{V}_k$，比较第 j 列得 $\boldsymbol{v}_j = \epsilon_j \boldsymbol{d}_{j-2} + \delta_j \boldsymbol{d}_{j-1} + \rho_j \boldsymbol{d}_j$，即

$$\boldsymbol{d}_j = \frac{\boldsymbol{v}_j - \delta_j \boldsymbol{d}_{j-1} - \epsilon_j \boldsymbol{d}_{j-2}}{\rho_j}.$$

设旋转后右端的第 j 个分量为 g_j，则小问题的解给出

$$\boldsymbol{x}_k = \boldsymbol{x}_0 + \boldsymbol{V}_k \boldsymbol{R}_k^{-1}(g_1, \dots, g_k)^{\top} = \boldsymbol{x}_0 + \boldsymbol{D}_k (g_1, \dots, g_k)^{\top}.$$

已确定的 g_j 此后不再改变，所以 $\boldsymbol{x}_j = \boldsymbol{x}_{j-1} + g_j \boldsymbol{d}_j$：这一更新等价于小问题的回代，却只需保留两个旧方向和少量旋转参数。$\rho_j = 0$ 意味着小问题秩亏，只可能在 $\boldsymbol{A}$ 奇异时出现，需要单独处理。

12.5.2 算法实现

输入与初始化 输入为实对称非奇异矩阵 $\boldsymbol{A}$ 与 $\boldsymbol{b}$，允许 $\boldsymbol{A}$ 不定；超参数为 $\boldsymbol{x}_0, \mathrm{atol}, \mathrm{rtol}, K$，输出为 $\boldsymbol{x}$。先算 $\boldsymbol{r}_0 = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_0$ 并按公共准则检查，已达标则直接输出；未结束时令 $\beta = \|\boldsymbol{r}_0\|_2$，取 $\boldsymbol{v}_0 = \boldsymbol{0}$、$\boldsymbol{v}_1 = \boldsymbol{r}_0/\beta$、$\gamma_0 = 0$、$\boldsymbol{d}_{-1} = \boldsymbol{d}_0 = \boldsymbol{0}$、$\bar{g}_1 = \beta$，并把两个尚不存在的旧旋转置为 $(c_{-1}, s_{-1}) = (c_0, s_0) = (1, 0)$。

Lanczos 三项递推 第 j 轮先作一步 Lanczos 递推：

$$\boldsymbol{w} = \boldsymbol{A}\boldsymbol{v}_j - \gamma_{j-1}\boldsymbol{v}_{j-1}, \qquad a_j = \boldsymbol{v}_j^{\top}\boldsymbol{w},$$
$$\boldsymbol{w} \leftarrow \boldsymbol{w} - a_j \boldsymbol{v}_j, \qquad \gamma_j = \|\boldsymbol{w}\|_2.$$

三对角矩阵的第 j 列因而为 $(\gamma_{j-1}, a_j, \gamma_j)^{\top}$，位于第 $j-1, j, j+1$ 行。此时只计算 γ_j，归一化留到本轮末尾。

旋转消元 然后按 GMRES 的旋转约定处理这一列：第 $j-2$ 个旋转作用于第 $j-2, j-1$ 行的 $(0, \gamma_{j-1})$，第 $j-1$ 个旋转作用于所得的第二个分量与 a_j，最后构造消去 γ_j 的新旋转：

$$\begin{aligned} \epsilon_j &= s_{j-2}\gamma_{j-1}, \qquad \theta = c_{j-2}\gamma_{j-1}, \\ \delta_j &= c_{j-1}\theta + s_{j-1}a_j, \qquad \bar{\delta} = -s_{j-1}\theta + c_{j-1}a_j, \\ \rho_j &= \sqrt{\bar{\delta}^2 + \gamma_j^2}, \qquad c_j = \bar{\delta}/\rho_j, \qquad s_j = \gamma_j/\rho_j. \end{aligned}$$

旋转后，三角因子的第 j 列只有 $\epsilon_j, \delta_j, \rho_j$ 三个非零元，分别位于第 $j-2, j-1, j$ 行。

更新解与停止 最后更新右端、方向与解：

$$\begin{aligned} g_j &= c_j \bar{g}_j, \qquad \bar{g}_{j+1} = -s_j \bar{g}_j, \\ \boldsymbol{d}_j &= \frac{\boldsymbol{v}_j - \delta_j \boldsymbol{d}_{j-1} - \epsilon_j \boldsymbol{d}_{j-2}}{\rho_j}, \qquad \boldsymbol{x}_j = \boldsymbol{x}_{j-1} + g_j \boldsymbol{d}_j. \end{aligned}$$

$|\bar{g}_{j+1}|$ 是当前残差长度的内部估计，用它按公共准则判断是否终止并输出 $\boldsymbol{x}_j$。若 $\gamma_j = 0$，子空间不再扩张，完成本轮的解更新后即结束；未结束时才令 $\boldsymbol{v}_{j+1} = \boldsymbol{w}/\gamma_j$ 进入下一轮。非奇异条件保证正常步骤中 $\rho_j > 0$；若出现 $\rho_j = 0$，先检查小问题的秩与相容性，不执行除法。退出前用 $\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_j$ 复核真实残差。

示例 12.9 对称不定矩阵上的 MINRES 取 $\boldsymbol{A} = \operatorname{diag}(1, -2)$，$\boldsymbol{b} = (1, 1)^{\mathsf{T}}$，$\boldsymbol{x}_0 = \boldsymbol{0}$。$\boldsymbol{A}$ 有一个正特征值和一个负特征值；若套用 CG，第一个方向 $\boldsymbol{p}_0 = \boldsymbol{b}$ 给出 $\boldsymbol{p}_0^{\mathsf{T}}\boldsymbol{A}\boldsymbol{p}_0 = 1 - 2 = -1 < 0$，能量范数的前提不成立。MINRES 只需要对称性。

初始化得 $\beta = \sqrt{2}$，$\boldsymbol{v}_1 = (1, 1)^{\mathsf{T}}/\sqrt{2}$。第一轮 $\boldsymbol{A}\boldsymbol{v}_1 = (1, -2)^{\mathsf{T}}/\sqrt{2}$，$a_1 = -1/2$，扣除后 $\boldsymbol{w} = (3/2, -3/2)^{\mathsf{T}}/\sqrt{2}$，故 $\gamma_1 = 3/2$，$\boldsymbol{v}_2 = (1, -1)^{\mathsf{T}}/\sqrt{2}$。第一列小向量为 $(a_1, \gamma_1) = (-1/2, 3/2)$，没有旧旋转，$\rho_1 = \sqrt{10}/2$，$c_1 = -1/\sqrt{10}$，$s_1 = 3/\sqrt{10}$；于是 $g_1 = c_1\beta = -1/\sqrt{5}$，$\bar{g}_2 = -s_1\beta = -3/\sqrt{5}$。方向 $\boldsymbol{d}_1 = \boldsymbol{v}_1/\rho_1 = (1, 1)^{\mathsf{T}}/\sqrt{5}$，解 $\boldsymbol{x}_1 = g_1\boldsymbol{d}_1 = (-1/5, -1/5)^{\mathsf{T}}$。直接计算 $\boldsymbol{r}_1 = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_1 = (6/5, 3/5)^{\mathsf{T}}$，长度 $3/\sqrt{5} = |\bar{g}_2|$。

第二轮 $\boldsymbol{w} = \boldsymbol{A}\boldsymbol{v}_2 - \gamma_1\boldsymbol{v}_1 = (-1/2, 1/2)^{\mathsf{T}}/\sqrt{2}$，$a_2 = -1/2$，扣除后余项为零，$\gamma_2 = 0$。这时

$$\boldsymbol{T}_2 = \begin{bmatrix} -1/2 & 3/2 \\ 3/2 & -1/2 \end{bmatrix},$$

第二列 $(\gamma_1, a_2, \gamma_2) = (3/2, -1/2, 0)$。第 0 个旋转是单位变换，故 $\epsilon_2 = 0$、$\theta = 3/2$；第一个旋转给出 $\delta_2 = c_1\theta + s_1 a_2 = -3/\sqrt{10}$，$\bar{\delta} = -s_1\theta + c_1 a_2 = -4/\sqrt{10}$；新旋转取 $\rho_2 = 4/\sqrt{10}$、$c_2 = -1$、$s_2 = 0$，于是 $g_2 = c_2 \bar{g}_2 = 3/\sqrt{5}$，$\bar{g}_3 = 0$。

由短递推，

$$\boldsymbol{d}_2 = \frac{\boldsymbol{v}_2 - \delta_2 \boldsymbol{d}_1}{\rho_2} = \frac{(2, -1/2)^{\top}}{\sqrt{5}}, \qquad \boldsymbol{x}_2 = \boldsymbol{x}_1 + g_2 \boldsymbol{d}_2 = \left(1, -\frac{1}{2}\right)^{\top},$$

代回得 $\boldsymbol{A}\boldsymbol{x}_2 = (1, 1)^{\top} = \boldsymbol{b}$。独立核验：直接解小问题 $\boldsymbol{T}_2 \boldsymbol{y} = \beta \boldsymbol{e}_1$，由第二行得 $y_2 = 3y_1$，再由第一行得 $4y_1 = \sqrt{2}$，即 $\boldsymbol{y} = (\sqrt{2}/4, 3\sqrt{2}/4)^{\top}$，而 $\boldsymbol{V}_2 \boldsymbol{y} = (1, -1/2)^{\top}$，与短递推的结果一致。

12.5.3 算法分析

正确性 MINRES 是 GMRES 在对称矩阵上的短递推实现，因而保留了 GMRES 的最小残差性。

定理 12.10 MINRES 的最小残差性 设 $\boldsymbol{A}$ 实对称非奇异，在精确算术下执行 MINRES 至第 k 步，且此前的 $\gamma_1, \dots, \gamma_{k-1}$ 均非零。则 $\boldsymbol{x}_k$ 与完整 GMRES 的第 k 个近似相同，是残差长度在 $\boldsymbol{x}_0 + \mathcal{K}_k$ 上的唯一最小点；$\|\boldsymbol{r}_k\|_2 = |\bar{g}_{k+1}|$ 随 k 不增，MINRES 至多 d 步得到精确解，并且

$$\|\boldsymbol{r}_k\|_2 \le \min_{p \in \mathcal{P}_k} \max_{\lambda \in \sigma(\boldsymbol{A})} |p(\lambda)| \, \|\boldsymbol{r}_0\|_2 .$$

证明 由(12.2)及 $\boldsymbol{V}_k$ 的标准正交性，$\boldsymbol{H}_k = \boldsymbol{V}_k^{\top} \boldsymbol{A} \boldsymbol{V}_k$；$\boldsymbol{A}$ 对称时它也对称。上 Hessenberg 矩阵在主对角线下方只有一条非零次对角线，对称后上方也只有一条，所以 $\boldsymbol{H}_k$ 是三对角矩阵，$h_{j-1,j} = h_{j,j-1} = \gamma_{j-1}$，Arnoldi 的投影只剩 Lanczos 递推中的两项。于是 $\boldsymbol{A}\boldsymbol{V}_k = \boldsymbol{V}_{k+1} \overline{\boldsymbol{T}}_k$，上述旋转正是 GMRES 对 $\overline{\boldsymbol{T}}_k$ 施加的旋转，所得上三角因子 $\boldsymbol{R}_k$ 上带宽为 2。由 $\boldsymbol{D}_k \boldsymbol{R}_k = \boldsymbol{V}_k$ 的第 j 列得到方向递推。GMRES 的解为 $\boldsymbol{x}_k = \boldsymbol{x}_0 + \boldsymbol{V}_k \boldsymbol{R}_k^{-1} (g_1, \dots, g_k)^{\top} = \boldsymbol{x}_0 + \boldsymbol{D}_k (g_1, \dots, g_k)^{\top}$，而右端已确定的分量此后不再改变，所以逐步加上 $g_j \boldsymbol{d}_j$ 得到的正是 GMRES 的近似。其余结论由定理 12.8得到；对称矩阵可取正交的特征向量矩阵 $\boldsymbol{X}$，$\kappa_2(\boldsymbol{X}) = 1$。 ■

收敛速度 界中只剩特征值，收敛快慢完全由谱决定。不定时特征值分布在原点两侧，而多项式在原点必须取 1，要同时压低两侧谱上的值，比只压低一侧更难。

奇异系统的边界 本节的结论假定 $\boldsymbol{A}$ 非奇异。若把 MINRES 用于奇异对称矩阵，不相容时最小残差不为零，判断是否到达最小二乘解要看 $\|\boldsymbol{A}\boldsymbol{r}_k\|_2$ 是否足够小，而不是看 $\|\boldsymbol{r}_k\|_2$；即使到达，普通 MINRES 给出的最小残差解也不自动具有最小欧氏范数。这里不展开奇异对称系统的专门算法（如 MINRES-QLP）。

数值敏感度与计算代价 浮点计算中 Lanczos 向量会失去正交性，残差估计 $|\bar{g}_{j+1}|$ 须用真实残差复核。每轮核心递推需要一次 $\boldsymbol{A}$ 乘向量，只保存 $\boldsymbol{v}_{j-1}, \boldsymbol{v}_j, \boldsymbol{w}, \boldsymbol{d}_{j-2}, \boldsymbol{d}_{j-1}, \boldsymbol{x}$ 等固定数量的向量，存储与完整 GMRES 的 kd 相比不随步数增长；若为保持正交性作完整的再正交化，就要保存全部基，存储随步数增长。

12.6 双共轭梯度法

12.6.1 主要思想

非对称矩阵上，Arnoldi 要对全部旧基向量投影，代价随步数增长。**双共轭梯度法**（biconjugate gradient method，BiCG）放弃残差最小化，改用 $\boldsymbol{A}$ 与 $\boldsymbol{A}^{\top}$ 同时生成两个序列：原序列位于 $\mathcal{K}_k(\boldsymbol{A}, \boldsymbol{r}_0)$，影子序列位于 $\mathcal{K}_k(\boldsymbol{A}^{\top}, \tilde{\boldsymbol{r}}_0)$。它不再要求原残差彼此正交，而要求原残差与影子残差相互正交，即**双正交**（biorthogonality）。这个条件只用相邻两项的递推就能维持，形式与 CG 相同，但不需要 CG 的正定误差内积。

具体地，维护原残差 $\boldsymbol{r}_k = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_k$ 与影子残差 $\tilde{\boldsymbol{r}}_k$，起点选满足 $\tilde{\boldsymbol{r}}_0^{\top}\boldsymbol{r}_0 \neq 0$ 的 $\tilde{\boldsymbol{r}}_0$。设计目标有两条：新原残差与旧影子方向正交；新原方向与旧影子方向关于 $\boldsymbol{A}$ 双共轭，即 $\tilde{\boldsymbol{p}}_i^{\top}\boldsymbol{A}\boldsymbol{p}_j = 0$（$i \neq j$）。下面像 CG 那样逐项推出步长与组合系数，记 $\rho_k = \tilde{\boldsymbol{r}}_k^{\top}\boldsymbol{r}_k$。

两个残差用同一个步长更新：$\boldsymbol{r}_{k+1} = \boldsymbol{r}_k - \alpha_k \boldsymbol{A}\boldsymbol{p}_k$，$\tilde{\boldsymbol{r}}_{k+1} = \tilde{\boldsymbol{r}}_k - \alpha_k \boldsymbol{A}^{\top}\tilde{\boldsymbol{p}}_k$。要求 $\tilde{\boldsymbol{p}}_k^{\top}\boldsymbol{r}_{k+1} = 0$，得 $\alpha_k = \tilde{\boldsymbol{p}}_k^{\top}\boldsymbol{r}_k / (\tilde{\boldsymbol{p}}_k^{\top}\boldsymbol{A}\boldsymbol{p}_k)$。影子方向取 $\tilde{\boldsymbol{p}}_k = \tilde{\boldsymbol{r}}_k + \beta_{k-1}\tilde{\boldsymbol{p}}_{k-1}$，上一步已保证 $\tilde{\boldsymbol{p}}_{k-1}^{\top}\boldsymbol{r}_k = 0$，所以分子化为 ρ_k：

$$\alpha_k = \frac{\rho_k}{\tilde{\boldsymbol{p}}_k^{\top}\boldsymbol{A}\boldsymbol{p}_k}.$$

组合系数由双共轭条件决定。把 $\boldsymbol{p}_{k+1} = \boldsymbol{r}_{k+1} + \beta_k \boldsymbol{p}_k$ 代入 $\tilde{\boldsymbol{p}}_k^{\top}\boldsymbol{A}\boldsymbol{p}_{k+1} = 0$，先得 $\beta_k = -\tilde{\boldsymbol{p}}_k^{\top}\boldsymbol{A}\boldsymbol{r}_{k+1} / (\tilde{\boldsymbol{p}}_k^{\top}\boldsymbol{A}\boldsymbol{p}_k)$。由影子残差的更新，$\boldsymbol{A}^{\top}\tilde{\boldsymbol{p}}_k = (\tilde{\boldsymbol{r}}_k - \tilde{\boldsymbol{r}}_{k+1})/\alpha_k$，

于是分子 $\tilde{\boldsymbol{p}}_k^{\top}\boldsymbol{A}\boldsymbol{r}_{k+1} = (\tilde{\boldsymbol{r}}_k^{\top}\boldsymbol{r}_{k+1} - \rho_{k+1})/\alpha_k = -\rho_{k+1}/\alpha_k$，这里用到双正交 $\tilde{\boldsymbol{r}}_k^{\top}\boldsymbol{r}_{k+1} = 0$。分母为 ρ_k/α_k，所以

$$\beta_k = \frac{\rho_{k+1}}{\rho_k},$$

原、影子两个新方向使用同一个 β_k。

与 CG 不同，ρ_k 与 $\tilde{\boldsymbol{p}}_k^{\top}\boldsymbol{A}\boldsymbol{p}_k$ 不受正定性保护，残差非零时也可能为零。因此任一关键内积为零时，需要区分两种情形：原残差已经为零是收敛，残差非零而配对量为零则是双正交构造失败。

12.6.2 算法实现

输入与初始化 输入为实非奇异方阵 $\boldsymbol{A}$ 与 $\boldsymbol{b}$，算法需要计算 $\boldsymbol{A}$ 与 $\boldsymbol{A}^{\top}$ 乘向量；超参数为 $\boldsymbol{x}_0, \mathrm{atol}, \mathrm{rtol}, K$ 及影子初值 $\tilde{\boldsymbol{r}}_0$，输出为 $\boldsymbol{x}$。先算 $\boldsymbol{r}_0 = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_0$ 并按公共准则检查，已达标则直接输出；未结束时选取满足 $\tilde{\boldsymbol{r}}_0^{\top}\boldsymbol{r}_0 \neq 0$ 的影子初值，默认 $\tilde{\boldsymbol{r}}_0 = \boldsymbol{r}_0$，再取 $\boldsymbol{p}_0 = \boldsymbol{r}_0$、$\tilde{\boldsymbol{p}}_0 = \tilde{\boldsymbol{r}}_0$、$\rho_0 = \tilde{\boldsymbol{r}}_0^{\top}\boldsymbol{r}_0$。

两个序列同步更新 第 k 轮先计算 $\boldsymbol{q}_k = \boldsymbol{A}\boldsymbol{p}_k$ 和 $\tilde{\boldsymbol{q}}_k = \boldsymbol{A}^{\top}\tilde{\boldsymbol{p}}_k$，检查分母 $\tilde{\boldsymbol{p}}_k^{\top}\boldsymbol{q}_k$ 非零后，以 $\alpha_k = \rho_k/(\tilde{\boldsymbol{p}}_k^{\top}\boldsymbol{q}_k)$ 同时更新解和两个残差：

$$\begin{aligned} \boldsymbol{x}_{k+1} &= \boldsymbol{x}_k + \alpha_k \boldsymbol{p}_k, \\ \boldsymbol{r}_{k+1} = \boldsymbol{r}_k - \alpha_k \boldsymbol{q}_k, &\qquad \tilde{\boldsymbol{r}}_{k+1} = \tilde{\boldsymbol{r}}_k - \alpha_k \tilde{\boldsymbol{q}}_k. \end{aligned}$$

停止检验与新方向 然后按公共准则检验原残差与步数上限。未结束时计算 $\rho_{k+1} = \tilde{\boldsymbol{r}}_{k+1}^{\top}\boldsymbol{r}_{k+1}$、$\beta_k = \rho_{k+1}/\rho_k$，再取

$$\boldsymbol{p}_{k+1} = \boldsymbol{r}_{k+1} + \beta_k \boldsymbol{p}_k, \qquad \tilde{\boldsymbol{p}}_{k+1} = \tilde{\boldsymbol{r}}_{k+1} + \beta_k \tilde{\boldsymbol{p}}_k.$$

这些公式要求尚未结束时的配对分母 ρ_k 与 $\tilde{\boldsymbol{p}}_k^{\top}\boldsymbol{A}\boldsymbol{p}_k$ 非零。零残差先由停止检验结束；残差非零而配对量为零时递推中断，不再继续相除，也不能把它当作收敛。退出时应区分三种原因：达到精度、配对量为零的中断、步数上限或残差长期不降的停滞。

示例 12.11 非对称二阶系统上的 BiCG 取 $\boldsymbol{A}$ 的行为 $(4,1)$ 与 $(2,3)$，$\boldsymbol{b} = (1,2)^{\top}$，$\boldsymbol{x}_0 = \boldsymbol{0}$，影子初值 $\tilde{\boldsymbol{r}}_0 = \boldsymbol{r}_0 = (1,2)^{\top}$，于是 $\rho_0 = 5$。第一轮 $\boldsymbol{q}_0 = \boldsymbol{A}\boldsymbol{p}_0 = (6,8)^{\top}$，$\tilde{\boldsymbol{q}}_0 = \boldsymbol{A}^{\top}\tilde{\boldsymbol{p}}_0 = (8,7)^{\top}$，分母 $\tilde{\boldsymbol{p}}_0^{\top}\boldsymbol{q}_0 = 22$，$\alpha_0 = 5/22$。更新得

$$\boldsymbol{x}_1 = \Big(\frac{5}{22}, \frac{5}{11}\Big)^{\top}, \qquad \boldsymbol{r}_1 = \Big(-\frac{4}{11}, \frac{2}{11}\Big)^{\top}, \qquad \tilde{\boldsymbol{r}}_1 = \Big(-\frac{9}{11}, \frac{9}{22}\Big)^{\top}.$$

可以核对双正交关系 $\tilde{\boldsymbol{r}}_0^{\top}\boldsymbol{r}_1 = -4/11 + 4/11 = 0$。再算 $\rho_1 = \tilde{\boldsymbol{r}}_1^{\top}\boldsymbol{r}_1 = 45/121$，$\beta_0 = 9/121$，新方向为 $\boldsymbol{p}_1 = (-35/121, 40/121)^{\top}$，$\tilde{\boldsymbol{p}}_1 = (-90/121, 135/242)^{\top}$。

第二轮 $\boldsymbol{q}_1 = \boldsymbol{A}\boldsymbol{p}_1 = (-100/121, 50/121)^{\top}$，$\tilde{\boldsymbol{p}}_0^{\top}\boldsymbol{q}_1 = 0$ 印证了双共轭；$\alpha_1 = \rho_1/(\tilde{\boldsymbol{p}}_1^{\top}\boldsymbol{q}_1) = 11/25$，得 $\boldsymbol{x}_2 = \boldsymbol{x}_1 + \alpha_1\boldsymbol{p}_1 = (1/10, 3/5)^{\top}$。代回两行方程，$4/10 + 3/5 = 1$，$2/10 + 9/5 = 2$，原残差为零。$\boldsymbol{A}$ 不对称，CG 的前提不成立，但 BiCG 借助影子序列维持了双正交与双共轭，在二维问题上同样两步结束。

12.6.3 算法分析

正确性 BiCG 选取近似的依据是下面的双正交关系，证明沿用 CG 的归纳，只是把每个内积的左因子换成影子序列。

定理 12.12 BiCG 的双正交性 设在精确算术下 BiCG 执行到第 k 步，此前的 $\rho_0, \dots, \rho_k$ 与 $\tilde{\boldsymbol{p}}_i^{\top}\boldsymbol{A}\boldsymbol{p}_i$（$i < k$）均非零。则对 $i, j \le k$、$i \neq j$，

$$\tilde{\boldsymbol{r}}_i^{\top}\boldsymbol{r}_j = 0, \qquad \tilde{\boldsymbol{p}}_i^{\top}\boldsymbol{A}\boldsymbol{p}_j = 0,$$

并且 $\boldsymbol{r}_k \perp \mathcal{K}_k(\boldsymbol{A}^{\top}, \tilde{\boldsymbol{r}}_0)$。这个正交条件确定了 BiCG 在 $\boldsymbol{x}_0 + \mathcal{K}_k$ 中选取的近似。

证明 对 k 归纳，设结论对 k 成立。由递推，$\boldsymbol{p}_i$ 与 $\boldsymbol{r}_0, \dots, \boldsymbol{r}_i$ 张成同一空间，$\tilde{\boldsymbol{p}}_i$ 与 $\tilde{\boldsymbol{r}}_0, \dots, \tilde{\boldsymbol{r}}_i$ 亦然，故 $\tilde{\boldsymbol{p}}_i^{\top}\boldsymbol{r}_k = 0$（$i < k$），从而 $\tilde{\boldsymbol{p}}_k^{\top}\boldsymbol{r}_k = \tilde{\boldsymbol{r}}_k^{\top}\boldsymbol{r}_k = \rho_k$。步长 α_k 因此使 $\tilde{\boldsymbol{p}}_k^{\top}\boldsymbol{r}_{k+1} = \rho_k - \alpha_k\tilde{\boldsymbol{p}}_k^{\top}\boldsymbol{A}\boldsymbol{p}_k = 0$；对 $i < k$，$\tilde{\boldsymbol{p}}_i^{\top}\boldsymbol{r}_{k+1} = \tilde{\boldsymbol{p}}_i^{\top}\boldsymbol{r}_k - \alpha_k\tilde{\boldsymbol{p}}_i^{\top}\boldsymbol{A}\boldsymbol{p}_k = 0$。所以 $\boldsymbol{r}_{k+1}$ 与 $\tilde{\boldsymbol{r}}_0, \dots, \tilde{\boldsymbol{r}}_k$ 都正交；把两个序列的角色互换，同理 $\tilde{\boldsymbol{r}}_{k+1}$ 与 $\boldsymbol{r}_0, \dots, \boldsymbol{r}_k$ 正交。

再看共轭。由 $\boldsymbol{A}^{\top}\tilde{\boldsymbol{p}}_i = (\tilde{\boldsymbol{r}}_i - \tilde{\boldsymbol{r}}_{i+1})/\alpha_i$，对 $i < k$ 有 $\tilde{\boldsymbol{p}}_i^{\top}\boldsymbol{A}\boldsymbol{r}_{k+1} = 0$，于是 $\tilde{\boldsymbol{p}}_i^{\top}\boldsymbol{A}\boldsymbol{p}_{k+1} = \tilde{\boldsymbol{p}}_i^{\top}\boldsymbol{A}\boldsymbol{r}_{k+1} + \beta_k\tilde{\boldsymbol{p}}_i^{\top}\boldsymbol{A}\boldsymbol{p}_k = 0$。对 $i = k$，$\tilde{\boldsymbol{p}}_k^{\top}\boldsymbol{A}\boldsymbol{r}_{k+1} = -\rho_{k+1}/\alpha_k$，而 $\beta_k\tilde{\boldsymbol{p}}_k^{\top}\boldsymbol{A}\boldsymbol{p}_k = (\rho_{k+1}/\rho_k)(\rho_k/\alpha_k) = \rho_{k+1}/\alpha_k$，两者抵消。由 $\boldsymbol{A}\boldsymbol{p}_i = (\boldsymbol{r}_i - \boldsymbol{r}_{i+1})/\alpha_i$，同理得 $\tilde{\boldsymbol{p}}_{k+1}^{\top}\boldsymbol{A}\boldsymbol{p}_i = 0$（$i \le k$）。最后，$\rho_i \neq 0$ 与双正交性给出 $\tilde{\boldsymbol{r}}_0, \dots, \tilde{\boldsymbol{r}}_{k-1}$ 线性无关：若 $\sum_i c_i\tilde{\boldsymbol{r}}_i = \boldsymbol{0}$，与 $\boldsymbol{r}_j$ 作内积得 $c_j\rho_j = 0$。它们都属于 $\mathcal{K}_k(\boldsymbol{A}^{\top}, \tilde{\boldsymbol{r}}_0)$，因而张成该空间，$\boldsymbol{r}_k$ 与之正交。 ∎

收敛性与数值敏感度 双正交条件不是某个范数的最小化，BiCG 因而没有 CG 或 GMRES 那样的单调最小性，残差可能上下波动，一般也不存在只靠 $\kappa_2(\boldsymbol{A})$ 就能承诺的统一下降速度。即使原方程有唯一解，配对量也可

能在残差非零时为零，使递推中断；配对量很小时，除以它会放大已有的舍入误差，残差可能剧烈振荡。这里保留这一限制，不展开中断的分类与修补策略。

计算代价 每轮需要一次 $\boldsymbol{A}$ 乘向量和一次 $\boldsymbol{A}^{\top}$ 乘向量，工作向量数量固定，存储不随步数增长。与 GMRES 相比，它以失去最小残差性和需要转置作用为代价换取短递推；若 $\boldsymbol{A}^{\top}$ 的作用难以获得，这一方法就不适用。

12.7 稳定化双共轭梯度法

12.7.1 主要思想

BiCG 每轮需要 $\boldsymbol{A}^{\top}$ 的作用，残差也可能剧烈振荡。**稳定化双共轭梯度法**（biconjugate gradient stabilized method，BiCGSTAB）只用一个固定的影子向量 $\hat{\boldsymbol{r}}$ 计算 BiCG 型递推所需的配对系数，不再生成影子序列。每轮先沿 BiCG 型方向走一步，得到中间残差；再沿 $\boldsymbol{A}$ 作用于中间残差的方向作一次一元最小化，把残差压低。这样每轮只需要 $\boldsymbol{A}$ 的作用。下面先推出两个半步的系数，再说明方向的组合系数为什么可以只用固定影子向量算出。

第一个半步沿当前方向 $\boldsymbol{p}_k$ 修正。记 $\rho_k = \hat{\boldsymbol{r}}^{\top}\boldsymbol{r}_k$、$\boldsymbol{v}_k = \boldsymbol{A}\boldsymbol{p}_k$，要求中间残差 $\boldsymbol{s}_k = \boldsymbol{r}_k - \alpha_k \boldsymbol{v}_k$ 与影子向量正交，即 $\hat{\boldsymbol{r}}^{\top}\boldsymbol{s}_k = 0$，得

$$\alpha_k = \frac{\rho_k}{\hat{\boldsymbol{r}}^{\top}\boldsymbol{v}_k}.$$

第二个半步令 $\boldsymbol{t}_k = \boldsymbol{A}\boldsymbol{s}_k$，沿 $\boldsymbol{s}_k$ 修正原变量，新残差为 $\boldsymbol{s}_k - \omega \boldsymbol{t}_k$。展开它的平方长度得 $\boldsymbol{s}_k^{\top}\boldsymbol{s}_k - 2\omega\, \boldsymbol{t}_k^{\top}\boldsymbol{s}_k + \omega^2 \boldsymbol{t}_k^{\top}\boldsymbol{t}_k$，这是 ω 的一元二次式，$\boldsymbol{t}_k \neq \boldsymbol{0}$ 时在

$$\omega_k = \frac{\boldsymbol{t}_k^{\top}\boldsymbol{s}_k}{\boldsymbol{t}_k^{\top}\boldsymbol{t}_k}$$

处取最小值。两次修正合并为 $\boldsymbol{x}_{k+1} = \boldsymbol{x}_k + \alpha_k \boldsymbol{p}_k + \omega_k \boldsymbol{s}_k$。

剩下的问题是新方向。为此在精确算术且尚未中断的条件下，用残差多项式描述 BiCG。由 BiCG 的递推，存在多项式 P_k, T_k 使 BiCG 的残差与方向为 $P_k(\boldsymbol{A})\boldsymbol{r}_0$ 与 $T_k(\boldsymbol{A})\boldsymbol{r}_0$，满足

$$P_0 = T_0 = 1, \qquad P_{k+1} = P_k - \alpha_k^{B} z T_k, \qquad T_k = P_k + \beta_{k-1}^{B} T_{k-1},$$

其中 $\alpha_k^{B}, \beta_k^{B}$ 是 BiCG 的系数。BiCGSTAB 再乘上平滑多项式 $Q_k(z) = \prod_{j<k}(1-\omega_j z)$，要使实际的残差与方向满足

$$\boldsymbol{r}_k = Q_k(\boldsymbol{A})P_k(\boldsymbol{A})\boldsymbol{r}_0, \qquad \boldsymbol{p}_k = Q_k(\boldsymbol{A})T_k(\boldsymbol{A})\boldsymbol{r}_0.$$

若这一对应在第 k 轮成立且 $\alpha_k=\alpha_k^B$，则 $\boldsymbol{s}_k=Q_k(\boldsymbol{A})(P_k-\alpha_k zT_k)(\boldsymbol{A})\boldsymbol{r}_0=Q_k(\boldsymbol{A})P_{k+1}(\boldsymbol{A})\boldsymbol{r}_0$，再乘 $(1-\omega_k\boldsymbol{A})$ 就得到 $\boldsymbol{r}_{k+1}=Q_{k+1}(\boldsymbol{A})P_{k+1}(\boldsymbol{A})\boldsymbol{r}_0$。

方向关系 $T_{k+1}=P_{k+1}+\beta_k^B T_k$ 两边乘以 Q_{k+1}，并代入 $Q_{k+1}=(1-\omega_k z)Q_k$，逐项得到

$$\boldsymbol{p}_{k+1}=\boldsymbol{r}_{k+1}+\beta_k^B(\boldsymbol{p}_k-\omega_k\boldsymbol{A}\boldsymbol{p}_k)=\boldsymbol{r}_{k+1}+\beta_k^B(\boldsymbol{p}_k-\omega_k\boldsymbol{v}_k).$$

这解释了方向更新为何保留“旧方向减去旧矩阵作用”。还需要两件事：用固定影子向量算出 β_k^B，并确认 $\alpha_k=\alpha_k^B$。

两者都由一个线性泛函得到。取 $\hat{\boldsymbol{r}}=\tilde{\boldsymbol{r}}_0$，定义 $L[f]=\hat{\boldsymbol{r}}^{\top}f(\boldsymbol{A})\boldsymbol{r}_0$。BiCG 的影子残差与影子方向使用同样的系数，分别是 $P_i(\boldsymbol{A}^{\top})\tilde{\boldsymbol{r}}_0$ 与 $T_i(\boldsymbol{A}^{\top})\tilde{\boldsymbol{r}}_0$，前 k 个影子残差张成 $\mathcal{K}_k(\boldsymbol{A}^{\top},\hat{\boldsymbol{r}})$，所以定理 12.12的双正交性写成 $L[z^jP_k]=0$（$j<k$）；同理，双共轭性给出 $L[z^{j+1}T_k]=0$（$j<k$）。记 P_k 与 Q_k 的首项系数分别为 π_k 与 χ_k；T_k 与 P_k 只差低次项，首项系数也是 π_k。

在归纳假设 $\boldsymbol{r}_k=Q_k(\boldsymbol{A})P_k(\boldsymbol{A})\boldsymbol{r}_0$、$\boldsymbol{p}_k=Q_k(\boldsymbol{A})T_k(\boldsymbol{A})\boldsymbol{r}_0$ 下，把各个配对量写成 L 的值；乘积中与 P_k 或 zT_k 相乘的低次项都被上面的正交关系消去，只剩首项的贡献：

$$\rho_k^B=L[P_k^2]=\pi_kL[z^kP_k],\qquad \rho_k=L[Q_kP_k]=\chi_kL[z^kP_k],$$

其中 ρ_k^B 是 BiCG 的配对量 $\tilde{\boldsymbol{r}}_k^{\top}P_k(\boldsymbol{A})\boldsymbol{r}_0$，影子残差 $\tilde{\boldsymbol{r}}_k=P_k(\boldsymbol{A}^{\top})\tilde{\boldsymbol{r}}_0$ 使它等于 $L[P_k^2]$。同样，BiCG 步长的分母 $\tilde{\boldsymbol{p}}_k^{\top}\boldsymbol{A}\,T_k(\boldsymbol{A})\boldsymbol{r}_0=L[zT_k^2]=\pi_kL[z^{k+1}T_k]$，而 $\hat{\boldsymbol{r}}^{\top}\boldsymbol{v}_k=L[zQ_kT_k]=\chi_kL[z^{k+1}T_k]$。两种步长中的 π_k 与 χ_k 分别约去，都等于 $L[z^kP_k]/L[z^{k+1}T_k]$，所以 $\alpha_k=\alpha_k^B$。

由两条多项式递推读出首项系数的比：$\pi_{k+1}/\pi_k=-\alpha_k$，$\chi_{k+1}/\chi_k=-\omega_k$。代入 $\beta_k^B=\rho_{k+1}^B/\rho_k^B$，

$$\beta_k^B=\frac{\pi_{k+1}}{\chi_{k+1}}\cdot\frac{\chi_k}{\pi_k}\cdot\frac{\rho_{k+1}}{\rho_k}=\frac{\alpha_k}{\omega_k}\cdot\frac{\rho_{k+1}}{\rho_k}.$$

实现中把它记为第 $k+1$ 轮的 β_{k+1}，只用固定影子向量的两个内积就能更新方向。

最后注意局部最小化的范围。第二个半步只保证 $\|\boldsymbol{s}_k-\omega_k\boldsymbol{t}_k\|_2\le\|\boldsymbol{s}_k\|_2$，即相对于中间残差有改进；它不保证新残差小于整轮开始时的 $\|\boldsymbol{r}_k\|_2$。

12.7.2 算法实现

输入与初始化 输入为实非奇异方阵 $\boldsymbol{A}$ 与 $\boldsymbol{b}$；超参数为 $\boldsymbol{x}_0$, atol, rtol, K 及固定的影子向量 $\hat{\boldsymbol{r}}$，输出为 $\boldsymbol{x}$。下面的写法参照文献中的模板[1]。先算 $\boldsymbol{r}_0=\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_0$ 并按公共准则检查，已达标则直接输出；未结束时取满足 $\hat{\boldsymbol{r}}^{\top}\boldsymbol{r}_0\neq0$ 的影子向量，默认 $\hat{\boldsymbol{r}}=\boldsymbol{r}_0$。

[1] R. Barrett, M. Berry, T. F. Chan, J. Demmel, J. M. Donato, J. Dongarra, V. Eijkhout, R. Pozo, C. Romine, H. van der Vorst, *Templates for the Solution of Linear Systems: Building Blocks for Iterative Methods*, SIAM, 1994, 2nd ed.

形成搜索方向 第 k 轮先算 $\rho_k = \widehat{\boldsymbol{r}}^{\top}\boldsymbol{r}_k$，再形成搜索方向。首轮取 $\boldsymbol{p}_0 = \boldsymbol{r}_0$；以后各轮用上一轮保存的 $\rho_{k-1}, \alpha_{k-1}, \omega_{k-1}, \boldsymbol{p}_{k-1}, \boldsymbol{v}_{k-1}$ 取

$$\beta_k = \frac{\rho_k}{\rho_{k-1}} \cdot \frac{\alpha_{k-1}}{\omega_{k-1}}, \qquad \boldsymbol{p}_k = \boldsymbol{r}_k + \beta_k(\boldsymbol{p}_{k-1} - \omega_{k-1}\boldsymbol{v}_{k-1}).$$

BiCG 半步 然后走第一个半步：

$$\boldsymbol{v}_k = \boldsymbol{A}\boldsymbol{p}_k, \qquad \alpha_k = \frac{\rho_k}{\widehat{\boldsymbol{r}}^{\top}\boldsymbol{v}_k}, \qquad \boldsymbol{s}_k = \boldsymbol{r}_k - \alpha_k\boldsymbol{v}_k,$$

$\boldsymbol{s}_k$ 是中间近似 $\boldsymbol{x}_k + \alpha_k\boldsymbol{p}_k$ 的残差。先用它检验中间近似：若满足公共准则，就输出 $\boldsymbol{x}_k + \alpha_k\boldsymbol{p}_k$，不再走第二个半步。

残差最小化半步 未结束时走第二个半步：

$$\boldsymbol{t}_k = \boldsymbol{A}\boldsymbol{s}_k, \qquad \omega_k = \frac{\boldsymbol{t}_k^{\top}\boldsymbol{s}_k}{\boldsymbol{t}_k^{\top}\boldsymbol{t}_k},$$

$$\boldsymbol{x}_{k+1} = \boldsymbol{x}_k + \alpha_k\boldsymbol{p}_k + \omega_k\boldsymbol{s}_k, \qquad \boldsymbol{r}_{k+1} = \boldsymbol{s}_k - \omega_k\boldsymbol{t}_k,$$

再按公共准则终止或进入下一轮，并保存下一轮所需的旧量。中间残差为零时已由前面的检验结束，避免在已求得解时计算 $0/0$。

中断的检查 未收敛时分别检查 $\rho_k = \widehat{\boldsymbol{r}}^{\top}\boldsymbol{r}_k$、$\widehat{\boldsymbol{r}}^{\top}\boldsymbol{v}_k$、$\boldsymbol{t}_k^{\top}\boldsymbol{t}_k$ 和 ω_k。若某个关键量为零，或相对于所涉向量长度的乘积过小，就报告中断，或者采用明确的重启策略（例如以当前残差重新选取影子向量）；不能把中断误报为残差达标。

示例 12.13 BiCGSTAB 在贯穿例上的一轮 仍取例 11.1的 $\boldsymbol{A}, \boldsymbol{b}$ 与 $\boldsymbol{x}_0 = \boldsymbol{0}$，影子向量 $\widehat{\boldsymbol{r}} = \boldsymbol{r}_0 = (1,2)^{\top}$。首轮 $\rho_0 = 5$，$\boldsymbol{p}_0 = \boldsymbol{r}_0$。第一个半步 $\boldsymbol{v}_0 = \boldsymbol{A}\boldsymbol{p}_0 = (6,7)^{\top}$，$\alpha_0 = 5/20 = 1/4$，$\boldsymbol{s}_0 = (-1/2, 1/4)^{\top}$，中间近似 $(1/4, 1/2)^{\top}$ 与 CG 第一步相同，$\|\boldsymbol{s}_0\|_2 = \sqrt{5}/4 \approx 0.559$。第二个半步 $\boldsymbol{t}_0 = \boldsymbol{A}\boldsymbol{s}_0 = (-7/4, 1/4)^{\top}$，$\boldsymbol{t}_0^{\top}\boldsymbol{s}_0 = 15/16$，$\boldsymbol{t}_0^{\top}\boldsymbol{t}_0 = 50/16$，故 $\omega_0 = 3/10$，于是

$$\boldsymbol{x}_1 = (1/4, 1/2)^{\top} + \tfrac{3}{10}\boldsymbol{s}_0 = (1/10, 23/40)^{\top},$$

$$\boldsymbol{r}_1 = \boldsymbol{s}_0 - \omega_0\boldsymbol{t}_0 = (1/40, 7/40)^{\top}.$$

直接计算 $\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_1$ 得到同一向量，$\|\boldsymbol{r}_1\|_2 = \sqrt{50}/40 \approx 0.177$，约为中间残差长度的三分之一。第一个半步给出的是与 CG 相同的点，残差的进一步下降来自第二个半步按 ω_0 所作的一维极小化。

示例 12.14 非对称二阶系统上的 BiCGSTAB 沿用例 12.11的 $\boldsymbol{A}$（行为 $(4,1)$ 与 $(2,3)$）、$\boldsymbol{b}=(1,2)^{\top}$ 与 $\boldsymbol{x}_0=\boldsymbol{0}$，取 $\hat{\boldsymbol{r}}=\boldsymbol{r}_0$。首轮 $\rho_0=5$，$\boldsymbol{v}_0=(6,8)^{\top}$，$\alpha_0=5/22$，中间残差 $\boldsymbol{s}_0=(-4/11,2/11)^{\top}$ 正是 BiCG 的 $\boldsymbol{r}_1$，与 $\boldsymbol{s}_0=Q_0P_1(\boldsymbol{A})\boldsymbol{r}_0$、$Q_0=1$ 相符。第二个半步 $\boldsymbol{t}_0=\boldsymbol{A}\boldsymbol{s}_0=(-14/11,-2/11)^{\top}$，$\boldsymbol{t}_0^{\top}\boldsymbol{s}_0=52/121$，$\boldsymbol{t}_0^{\top}\boldsymbol{t}_0=200/121$，故 $\omega_0=13/50$。两次修正给出

$$\boldsymbol{x}_1=\Big(\frac{73}{550},\frac{138}{275}\Big)^{\top},\qquad \boldsymbol{r}_1=\Big(-\frac{9}{275},\frac{63}{275}\Big)^{\top},$$

直接计算 $\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_1$ 得到同一向量；$\|\boldsymbol{r}_1\|_2\approx 0.231$，小于 $\|\boldsymbol{s}_0\|_2\approx 0.407$。

第二轮 $\rho_1=\hat{\boldsymbol{r}}^{\top}\boldsymbol{r}_1=117/275$，$\beta_1=(\rho_1/\rho_0)(\alpha_0/\omega_0)=9/121$，与 BiCG 的 β_0 相同；新方向 $\boldsymbol{p}_1=\boldsymbol{r}_1+\beta_1(\boldsymbol{p}_0-\omega_0\boldsymbol{v}_0)=(-9/121,27/121)^{\top}$。再算 $\boldsymbol{v}_1=\boldsymbol{A}\boldsymbol{p}_1=(-9/121,63/121)^{\top}$，$\alpha_1=(117/275)/(117/121)=11/25$，也与 BiCG 的 α_1 相同。这时中间残差 $\boldsymbol{s}_1=\boldsymbol{r}_1-\alpha_1\boldsymbol{v}_1=\boldsymbol{0}$，直接输出 $\boldsymbol{x}_1+\alpha_1\boldsymbol{p}_1=(1/10,3/5)^{\top}$，不再计算 $\boldsymbol{t}_1=\boldsymbol{0}$ 和 ω_1，避免零除。

12.7.3 算法分析

第二个半步的作用 第二个半步的系数来自一个一元二次式。展开

$$\|\boldsymbol{s}_k-\omega\boldsymbol{t}_k\|_2^2=\|\boldsymbol{s}_k\|_2^2-2\omega\,\boldsymbol{t}_k^{\top}\boldsymbol{s}_k+\omega^2\|\boldsymbol{t}_k\|_2^2,$$

它在 $\omega=\omega_k$ 处取最小值 $\|\boldsymbol{s}_k\|_2^2-(\boldsymbol{t}_k^{\top}\boldsymbol{s}_k)^2/\|\boldsymbol{t}_k\|_2^2$，所以 $\|\boldsymbol{r}_{k+1}\|_2\le\|\boldsymbol{s}_k\|_2$。这只是相对于中间残差的局部改进：第一个半步可能使 $\|\boldsymbol{s}_k\|_2$ 大于 $\|\boldsymbol{r}_k\|_2$，因而不保证 $\|\boldsymbol{r}_{k+1}\|_2\le\|\boldsymbol{r}_k\|_2$，也不保证在所有非奇异系统上收敛。收敛快慢取决于实际形成的残差多项式 Q_kP_k。

中断与数值敏感度 稳定化半步不消除 BiCG 的中断：ρ_k 或 $\hat{\boldsymbol{r}}^{\top}\boldsymbol{v}_k$ 为零的情形依然存在，另外还多了 $\omega_k=0$ 的可能，这时下一轮的 β 无法计算。影子配对量很小或 ω_k 很小时，后续系数对舍入敏感，所以仍按公共准则复核原残差。

计算代价 完整一轮通常需要两次 $\boldsymbol{A}$ 乘向量，不需要 $\boldsymbol{A}^{\top}$，使用固定数量的工作向量；在中间阶段终止时，只需要第一个半步的一次乘法。与 BiCG 相比，每轮的矩阵作用次数相同，但两次都是 $\boldsymbol{A}$，并多了一次局部平滑。

12.8 Golub–Kahan 双对角化

12.8.1 主要思想

对一般的 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$，残差在 m 维的数据空间，未知量在 d 维空间，不能像方阵那样反复乘 $\boldsymbol{A}$；把数据空间的向量送回未知量空间的是 $\boldsymbol{A}^{\top}$。Golub–Kahan 双对角化（Golub–Kahan bidiagonalization）因此交替作用 $\boldsymbol{A}$ 与 $\boldsymbol{A}^{\top}$，在数据空间建立标准正交基 $\boldsymbol{u}_1,\boldsymbol{u}_2,\dots$，在未知量空间建立与之配对的标准正交基 $\boldsymbol{v}_1,\boldsymbol{v}_2,\dots$。两组向量属于不同的空间，不能放进同一个正交化序列，只能各自在本空间内正交。

递推从右端开始。令 $\beta_1=\|\boldsymbol{b}\|_2$、$\boldsymbol{u}_1=\boldsymbol{b}/\beta_1$，把 $\boldsymbol{A}^{\top}\boldsymbol{u}_1$ 归一化为 $\alpha_1\boldsymbol{v}_1$。已有 $\boldsymbol{u}_k,\boldsymbol{v}_k$ 时，先把 $\boldsymbol{v}_k$ 送到数据空间，从 $\boldsymbol{A}\boldsymbol{v}_k$ 中扣除已经由 $\boldsymbol{u}_k$ 解释的分量 $\alpha_k\boldsymbol{u}_k$，令 $\beta_{k+1}\boldsymbol{u}_{k+1}=\boldsymbol{A}\boldsymbol{v}_k-\alpha_k\boldsymbol{u}_k$；再把 $\boldsymbol{u}_{k+1}$ 送回未知量空间，从 $\boldsymbol{A}^{\top}\boldsymbol{u}_{k+1}$ 中扣除 $\beta_{k+1}\boldsymbol{v}_k$，令 $\alpha_{k+1}\boldsymbol{v}_{k+1}=\boldsymbol{A}^{\top}\boldsymbol{u}_{k+1}-\beta_{k+1}\boldsymbol{v}_k$。两次的系数都取余项的长度。

扣除的系数正是已经算出的 α_k 与 β_{k+1}：由 $\boldsymbol{A}^{\top}\boldsymbol{u}_k=\beta_k\boldsymbol{v}_{k-1}+\alpha_k\boldsymbol{v}_k$，$\boldsymbol{u}_k^{\top}\boldsymbol{A}\boldsymbol{v}_k=\alpha_k$；由 $\boldsymbol{A}\boldsymbol{v}_k=\alpha_k\boldsymbol{u}_k+\beta_{k+1}\boldsymbol{u}_{k+1}$，$\boldsymbol{v}_k^{\top}\boldsymbol{A}^{\top}\boldsymbol{u}_{k+1}=\beta_{k+1}$。每步只扣除一项而仍保持全部正交性，由下面的定理 12.17用归纳证明。

把这些关系汇总，得到 $\boldsymbol{A}\boldsymbol{V}_k=\boldsymbol{U}_{k+1}\boldsymbol{B}_k$，其中 $\boldsymbol{B}_k$ 是对角元为 $\alpha_1,\dots,\alpha_k$、次对角元为 $\beta_2,\dots,\beta_{k+1}$ 的 $(k+1)\times k$ 下双对角矩阵；转置方向则是 $\boldsymbol{A}^{\top}\boldsymbol{U}_{k+1}=\boldsymbol{V}_k\boldsymbol{B}_k^{\top}+\alpha_{k+1}\boldsymbol{v}_{k+1}\boldsymbol{e}_{k+1}^{\top}$。后一式的边界项来自最后一个 $\boldsymbol{u}_{k+1}$ 被 $\boldsymbol{A}^{\top}$ 送回时产生的新方向，不能漏掉；若 $\alpha_{k+1}=0$，这一项直接为零，也不引入 $\boldsymbol{v}_{k+1}$。在这两组基下，长方矩阵问题被压缩成一个双对角的小问题。

两条作用关系相接，$\boldsymbol{v}_{k+1}$ 由 $\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{v}_k$ 减去 $\boldsymbol{v}_k,\boldsymbol{v}_{k-1}$ 的组合得到，所以右侧基张成 $\mathcal{K}_k(\boldsymbol{A}^{\top}\boldsymbol{A},\boldsymbol{A}^{\top}\boldsymbol{b})$。实际计算只用 $\boldsymbol{A}\boldsymbol{v}$ 与 $\boldsymbol{A}^{\top}\boldsymbol{u}$，不形成 $\boldsymbol{A}^{\top}\boldsymbol{A}$；有限精度下可按正交性的需要补做重正交化。它是后面 LSQR 和 LSMR 共用的内部过程，基向量和双对角系数只是求解器的中间状态，不作为输出。

12.8.2 算法实现

起步 输入仍是 $\boldsymbol{A}$ 与 $\boldsymbol{b}\in\mathbb{R}^m$。后面两种求解器都固定零初值 $\boldsymbol{x}_0=\boldsymbol{0}$，这是本节选出最小范数解的约定；生成多少步由求解器的步数上限 K 控制。起步先处理右端：若 $\boldsymbol{b}=\boldsymbol{0}$，零向量满足方程，也是最小范数解，直接输出。否则令

$$\beta_1=\|\boldsymbol{b}\|_2,\quad \boldsymbol{u}_1=\boldsymbol{b}/\beta_1,\quad \boldsymbol{q}=\boldsymbol{A}^{\top}\boldsymbol{u}_1,\quad \alpha_1=\|\boldsymbol{q}\|_2.$$

若 $\alpha_1=0$，则 $\boldsymbol{A}^{\top}\boldsymbol{b}=\boldsymbol{0}$，零向量已满足正规方程(9.5)，同样直接输出；其余情况令 $\boldsymbol{v}_1=\boldsymbol{q}/\alpha_1$。

交替扩展两组基　然后逐轮扩展两组基。第 k 轮先把当前的未知量方向 $\boldsymbol{v}_k$ 送到数据空间，减去它在 $\boldsymbol{u}_k$ 上的分量并归一化；再把得到的 $\boldsymbol{u}_{k+1}$ 送回未知量空间，减去它在 $\boldsymbol{v}_k$ 上的分量并归一化：

$$\begin{aligned} \boldsymbol{p} &= \boldsymbol{A}\boldsymbol{v}_k - \alpha_k \boldsymbol{u}_k, & \beta_{k+1} &= \|\boldsymbol{p}\|_2, \\ \boldsymbol{q} &= \boldsymbol{A}^{\top}\boldsymbol{u}_{k+1} - \beta_{k+1}\boldsymbol{v}_k, & \alpha_{k+1} &= \|\boldsymbol{q}\|_2, \end{aligned}$$

其中 $\beta_{k+1} \neq 0$ 时 $\boldsymbol{u}_{k+1} = \boldsymbol{p}/\beta_{k+1}$，$\alpha_{k+1} \neq 0$ 时 $\boldsymbol{v}_{k+1} = \boldsymbol{q}/\alpha_{k+1}$。减去的系数正是已经算出的 α_k 和 β_{k+1}，不需要另算内积；两次归一化分别发生在数据空间和未知量空间，所得长度就是新的双对角系数。

零系数的处理　最后处理零系数。若 $\beta_{k+1} = 0$，无法生成 $\boldsymbol{u}_{k+1}$，这时约定 $\alpha_{k+1} = 0$ 并停止生成；若 $\beta_{k+1} > 0$ 而 $\alpha_{k+1} = 0$，则不生成 $\boldsymbol{v}_{k+1}$，转置关系中的边界项按零处理。两种情况下，本轮已经取得的系数仍交给 LSQR 或 LSMR 完成旋转与解的更新，然后检查目标并结束求解，不在当前小问题解完之前提前返回。近零的系数用与数据尺度相配的阈值判断；基停止扩张也不等于原残差为零，不相容问题的原残差可以停在非零值上。

示例 12.15　直线拟合上的两步双对角化　沿用示例 9.4的 $\boldsymbol{A} = \left[\begin{smallmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{smallmatrix}\right]$ 与 $\boldsymbol{b} = (1,2,2)^{\top}$。起步得 $\beta_1 = 3$、$\boldsymbol{u}_1 = (1,2,2)^{\top}/3$；$\boldsymbol{A}^{\top}\boldsymbol{u}_1 = (5/3, 2)^{\top}$，故 $\alpha_1 = \sqrt{61}/3 \approx 2.6034$，$\boldsymbol{v}_1 = (5,6)^{\top}/\sqrt{61}$。

第一轮先把 $\boldsymbol{v}_1$ 送到数据空间并扣除 $\alpha_1\boldsymbol{u}_1$：

$$\boldsymbol{A}\boldsymbol{v}_1 = \frac{(5,11,17)^{\top}}{\sqrt{61}},$$

$$\boldsymbol{p} = \boldsymbol{A}\boldsymbol{v}_1 - \alpha_1\boldsymbol{u}_1 = \frac{(-16,-23,31)^{\top}}{9\sqrt{61}},$$

于是 $\beta_2 \approx 0.5944$，$\boldsymbol{u}_2 \approx (-0.3829, -0.5504, 0.7419)^{\top}$；再由 $\boldsymbol{A}^{\top}\boldsymbol{u}_2 - \beta_2\boldsymbol{v}_1$ 得 $\alpha_2 \approx 0.7446$，$\boldsymbol{v}_2 = (-6,5)^{\top}/\sqrt{61}$。第二轮得 $\beta_3 \approx 0.5607$，$\boldsymbol{u}_3 \approx (-0.8615, 0.5026, -0.0718)^{\top}$，而 $\boldsymbol{A}^{\top}\boldsymbol{u}_3 - \beta_3\boldsymbol{v}_2 = \boldsymbol{0}$，即 $\alpha_3 = 0$：未知量空间只有二维，已被 $\boldsymbol{v}_1, \boldsymbol{v}_2$ 取尽，生成到此为止。

核对：$\boldsymbol{u}_1, \boldsymbol{u}_2, \boldsymbol{u}_3$ 两两正交；$\boldsymbol{V}_2$ 是正交方阵，$\boldsymbol{A} = \boldsymbol{U}_3\boldsymbol{B}_2\boldsymbol{V}_2^{\top}$，所以 $\boldsymbol{B}_2^{\top}\boldsymbol{B}_2$ 与 $\boldsymbol{A}^{\top}\boldsymbol{A} = \left[\begin{smallmatrix} 3 & 3 \\ 3 & 5 \end{smallmatrix}\right]$ 有相同的迹 8 和行列式 6。数值上

$$\alpha_1^2 + \beta_2^2 + \alpha_2^2 + \beta_3^2 \approx 8.000,$$

$$\alpha_1^2\alpha_2^2 + \alpha_1^2\beta_3^2 + \beta_2^2\beta_3^2 \approx 6.000.$$

两个不变量都吻合。这项核对只用到双对角系数本身，不必重新比较各个基向量。

直线拟合的数据可以拟合到只剩一个非零的最优残差。下面换一个更简单的不相容系统，它的系数都有封闭形式，后面 LSQR 与 LSMR 的对照都用它作输入。

示例 12.16　不相容矩形系统上的双对角化　取 $\boldsymbol{A}=\left[\begin{smallmatrix}1&0\\0&2\\0&0\end{smallmatrix}\right]$，$\boldsymbol{b}=(1,1,1)^{\mathsf{T}}$。第三行恒为零，$\boldsymbol{b}$ 的第三个分量无法拟合，最小二乘解是 $\hat{\boldsymbol{x}}=(1,1/2)^{\mathsf{T}}$，最优残差为 $(0,0,1)^{\mathsf{T}}$。起步得 $\beta_1=\sqrt{3}$，$\boldsymbol{u}_1=(1,1,1)^{\mathsf{T}}/\sqrt{3}$；$\boldsymbol{A}^{\mathsf{T}}\boldsymbol{u}_1=(1,2)^{\mathsf{T}}/\sqrt{3}$，故 $\alpha_1=\sqrt{5/3}$，$\boldsymbol{v}_1=(1,2)^{\mathsf{T}}/\sqrt{5}$。

第一轮 $\boldsymbol{A}\boldsymbol{v}_1=(1,4,0)^{\mathsf{T}}/\sqrt{5}$，扣除 $\alpha_1\boldsymbol{u}_1=\sqrt{5}(1,1,1)^{\mathsf{T}}/3$ 得

$$\boldsymbol{A}\boldsymbol{v}_1-\alpha_1\boldsymbol{u}_1=\frac{(-2,7,-5)^{\mathsf{T}}}{3\sqrt{5}},$$

故 $\beta_2=\sqrt{78}/(3\sqrt{5})$，$\boldsymbol{u}_2=(-2,7,-5)^{\mathsf{T}}/\sqrt{78}$。再由 $\boldsymbol{A}^{\mathsf{T}}\boldsymbol{u}_2=(-2,14)^{\mathsf{T}}/\sqrt{78}$ 扣除 $\beta_2\boldsymbol{v}_1=\sqrt{78}(1,2)^{\mathsf{T}}/15$，得 $18(-2,1)^{\mathsf{T}}/(5\sqrt{78})$，因此 $\alpha_2=18\sqrt{5}/(5\sqrt{78})$，$\boldsymbol{v}_2=(-2,1)^{\mathsf{T}}/\sqrt{5}$。

第二轮 $\boldsymbol{A}\boldsymbol{v}_2-\alpha_2\boldsymbol{u}_2=5(-4,1,3)^{\mathsf{T}}/(13\sqrt{5})$，得 $\beta_3=\sqrt{10/13}$，$\boldsymbol{u}_3=(-4,1,3)^{\mathsf{T}}/\sqrt{26}$；而 $\boldsymbol{A}^{\mathsf{T}}\boldsymbol{u}_3=(-4,2)^{\mathsf{T}}/\sqrt{26}$ 恰好等于 $\beta_3\boldsymbol{v}_2$，所以 $\alpha_3=0$。逐列核验 $\boldsymbol{A}\boldsymbol{V}_2=\boldsymbol{U}_3\boldsymbol{B}_2$：第一列 $\alpha_1\boldsymbol{u}_1+\beta_2\boldsymbol{u}_2=(1,4,0)^{\mathsf{T}}/\sqrt{5}=\boldsymbol{A}\boldsymbol{v}_1$，第二列同理。右侧二维空间已经生成完毕，但 $\boldsymbol{b}$ 在第三行的分量仍不可拟合，原残差不会降到零。

12.8.3 算法分析

正确性　把前 k 轮的系数排成 $(k+1)\times k$ 的下双对角矩阵，并记 $\boldsymbol{U}_{k+1}=[\boldsymbol{u}_1\ \cdots\ \boldsymbol{u}_{k+1}]$、$\boldsymbol{V}_k=[\boldsymbol{v}_1\ \cdots\ \boldsymbol{v}_k]$：

$$\boldsymbol{B}_k=\begin{bmatrix}\alpha_1 & & & \\ \beta_2 & \alpha_2 & & \\ & \beta_3 & \ddots & \\ & & \ddots & \alpha_k \\ & & & \beta_{k+1}\end{bmatrix}.$$

下面的定理说明，短递推得到的两组基确实标准正交，并把递推整理成矩阵关系。

定理 12.17　Golub–Kahan 关系　设 $\alpha_1,\dots,\alpha_k$ 与 $\beta_2,\dots,\beta_{k+1}$ 都为正。则在精确算术中，$\boldsymbol{U}_{k+1}$ 与 $\boldsymbol{V}_k$ 的列分别标准正交，

$$\boldsymbol{A}\boldsymbol{V}_k=\boldsymbol{U}_{k+1}\boldsymbol{B}_k,\qquad \boldsymbol{A}^{\mathsf{T}}\boldsymbol{U}_{k+1}=\boldsymbol{V}_k\boldsymbol{B}_k^{\mathsf{T}}+\alpha_{k+1}\boldsymbol{v}_{k+1}\boldsymbol{e}_{k+1}^{\mathsf{T}},\tag{12.3}$$

其中 $\alpha_{k+1}=0$ 时末项为零；并且 $\operatorname{range}(\boldsymbol{V}_k)=\mathcal{K}_k(\boldsymbol{A}^{\top}\boldsymbol{A},\boldsymbol{A}^{\top}\boldsymbol{b})$。

证明 由 $\boldsymbol{p},\boldsymbol{q}$ 的定义，$\boldsymbol{A}\boldsymbol{v}_i=\alpha_i\boldsymbol{u}_i+\beta_{i+1}\boldsymbol{u}_{i+1}$，$\boldsymbol{A}^{\top}\boldsymbol{u}_i=\beta_i\boldsymbol{v}_{i-1}+\alpha_i\boldsymbol{v}_i$（约定 $\boldsymbol{v}_0=\boldsymbol{0}$），它们分别是(12.3)两式的第 i 列。正交性对 k 归纳。设 $\boldsymbol{u}_1,\dots,\boldsymbol{u}_k$ 与 $\boldsymbol{v}_1,\dots,\boldsymbol{v}_k$ 已分别标准正交，对 $j\le k$，由这两个列关系，

$$\begin{aligned}\beta_{k+1}\boldsymbol{u}_j^{\top}\boldsymbol{u}_{k+1}&=\boldsymbol{v}_k^{\top}\boldsymbol{A}^{\top}\boldsymbol{u}_j-\alpha_k\boldsymbol{u}_j^{\top}\boldsymbol{u}_k\\&=\boldsymbol{v}_k^{\top}(\beta_j\boldsymbol{v}_{j-1}+\alpha_j\boldsymbol{v}_j)-\alpha_k\delta_{j,k}=0.\end{aligned}$$

同理，由关系 $\boldsymbol{A}\boldsymbol{v}_j=\alpha_j\boldsymbol{u}_j+\beta_{j+1}\boldsymbol{u}_{j+1}$ 以及刚证明的 $\boldsymbol{u}$ 的正交性，$\alpha_{k+1}\boldsymbol{v}_j^{\top}\boldsymbol{v}_{k+1}=\beta_{j+1}\delta_{j,k}-\beta_{k+1}\delta_{j,k}=0$。最后，$\boldsymbol{v}_1\parallel\boldsymbol{A}^{\top}\boldsymbol{b}$，而 $\boldsymbol{v}_{i+1}$ 由 $\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{v}_i$ 减去 $\boldsymbol{v}_i,\boldsymbol{v}_{i-1}$ 的组合得到，归纳可知 $\boldsymbol{v}_i\in\mathcal{K}_i(\boldsymbol{A}^{\top}\boldsymbol{A},\boldsymbol{A}^{\top}\boldsymbol{b})$。$\boldsymbol{V}_k$ 的 k 列标准正交，而该 Krylov 空间至多 k 维，两者相等。 ■

因此零初值下双对角化生成的正是第 12.1节所说的长方矩阵 Krylov 空间，但从不形成 $\boldsymbol{A}^{\top}\boldsymbol{A}$。生成终止时，把未生成的基向量连同它的零系数从(12.3)中略去，两式仍成立。图 12.3把递推与矩阵关系放在一起：(a) 中进出 $\boldsymbol{v}_i$ 的两支箭头给出 α_i 与 β_{i+1}，它们正是 (b) 中 $\boldsymbol{B}_k$ 的第 i 列；每个新向量只与对面空间中相邻的一个向量相连，这就是每步只需扣除一项的原因。

数值稳定性 在浮点运算中，正交性所依赖的相消只近似成立，短递推也不会去掉舍入引入的旧方向分量，两组基会逐渐失去正交性；它对求解结果的影响交给两种求解器，由第 12.12节的真实残差复核来控制，必要时以保存基并重正交化的代价换取正交性。

计算代价 每轮至多一次 $\boldsymbol{A}$ 乘向量和一次 $\boldsymbol{A}^{\top}$ 乘向量，外加两次向量更新、两次范数和两次缩放。LSQR 与 LSMR 只用当前的 $\boldsymbol{u}_k,\boldsymbol{v}_k$，不保存整组基、不作完整再正交化时，工作存储为 $O(m+d)$。双对角化只负责生成候选空间，收敛快慢取决于下一步在子空间中怎样选取近似解。

12.9 LSQR 算法

12.9.1 主要思想

LSQR 由 Paige 与 Saunders 提出[2]。，它在 $\operatorname{range}(\boldsymbol{V}_k)$ 中直接最小化原残差。令 $\boldsymbol{x}=\boldsymbol{V}_k\boldsymbol{y}$，由 $\boldsymbol{b}=\beta_1\boldsymbol{u}_1=\boldsymbol{U}_{k+1}\beta_1\boldsymbol{e}_1$ 和(12.3)，

$$\boldsymbol{b}-\boldsymbol{A}\boldsymbol{V}_k\boldsymbol{y}=\boldsymbol{U}_{k+1}(\beta_1\boldsymbol{e}_1-\boldsymbol{B}_k\boldsymbol{y}).$$

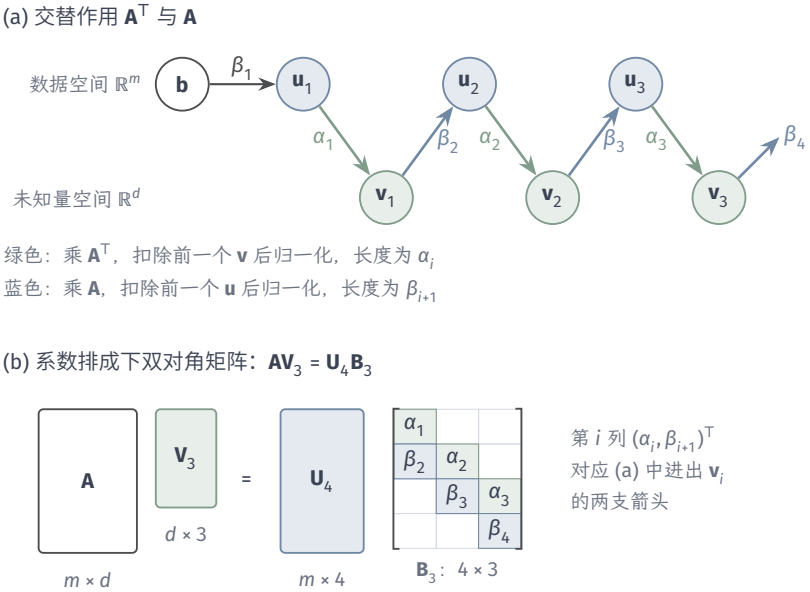


图 12.3 Golub–Kahan 双对角化的递推与矩阵关系（$k=3$）。(a) 蓝色 $\boldsymbol{u}_i$ 在数据空间，绿色 $\boldsymbol{v}_i$ 在未知量空间；乘 $\boldsymbol{A}^{\mathsf{T}}$ 并扣除前一个 $\boldsymbol{v}$ 后归一化得到 $\boldsymbol{v}_i$，长度为 α_i，乘 $\boldsymbol{A}$ 并扣除前一个 $\boldsymbol{u}$ 后归一化得到 $\boldsymbol{u}_{i+1}$，长度为 β_{i+1}。(b) 这些长度排成 4×3 的下双对角矩阵 $\boldsymbol{B}_3$，满足 $\boldsymbol{AV}_3=\boldsymbol{U}_4\boldsymbol{B}_3$；绿格为对角元，蓝格为次对角元，其余元素为零。

$\boldsymbol{U}_{k+1}$ 的列标准正交，不改变长度，所以第 k 步只需解一个 $(k+1)\times k$ 的双对角最小二乘问题：

$$\boldsymbol{x}_k=\boldsymbol{V}_k\boldsymbol{y}_k,\qquad \boldsymbol{y}_k=\arg\min_{\boldsymbol{y}\in\mathbb{R}^k}\|\beta_1\boldsymbol{e}_1-\boldsymbol{B}_k\boldsymbol{y}\|_2. \tag{12.4}$$

这一做法不要求 $\boldsymbol{A}$ 是方阵、满秩或相容，相容方程与不相容最小二乘问题都适用。

小问题的 QR 分解可以逐列延续。设前 $k-1$ 列已化为上三角，第 k、$k+1$ 两行待处理的是第 k 列的 $(\bar\rho_k,\beta_{k+1})$、新的第 $k+1$ 列的 $(0,\alpha_{k+1})$ 和右端的 $(\bar\phi_k,0)$。取 $\rho_k=\operatorname{hypot}(\bar\rho_k,\beta_{k+1})$、$c_k=\bar\rho_k/\rho_k$、$s_k=\beta_{k+1}/\rho_k$，把对称的正交变换 $\left[\begin{smallmatrix}c_k & s_k\\ s_k & -c_k\end{smallmatrix}\right]$ 作用于这两行：

$$\begin{bmatrix}c_k & s_k\\ s_k & -c_k\end{bmatrix}\begin{bmatrix}\bar\rho_k & 0 & \bar\phi_k\\ \beta_{k+1} & \alpha_{k+1} & 0\end{bmatrix}=\begin{bmatrix}\rho_k & \theta_{k+1} & \phi_k\\ 0 & \bar\rho_{k+1} & \bar\phi_{k+1}\end{bmatrix},$$

其中 $\theta_{k+1}=s_k\alpha_{k+1}$、$\bar\rho_{k+1}=-c_k\alpha_{k+1}$、$\phi_k=c_k\bar\phi_k$、$\bar\phi_{k+1}=s_k\bar\phi_k$。左下角为 $s_k\bar\rho_k-c_k\beta_{k+1}=0$，所以 β_{k+1} 被消去。这是 Paige 与 Saunders 原文的反射式约定；它与第 12.4节的旋转只差第二行的符号，$\bar\rho_{k+1}$ 与 $\bar\phi_{k+1}$ 随之变号，各量的绝对值和后面的残差估计都不变。

所得上三角因子 $\boldsymbol{R}_k$ 只有对角元 $\rho_1,\dots,\rho_k$ 与上副对角元 $\theta_2,\dots,\theta_k$，解因此可以逐列递推。记 $\boldsymbol{V}_k\boldsymbol{R}_k^{-1}$ 的第 i 列为 $\boldsymbol{w}_i/\rho_i$，比较 $(\boldsymbol{V}_k\boldsymbol{R}_k^{-1})\boldsymbol{R}_k=\boldsymbol{V}_k$ 的第 $i+1$ 列，得 $\theta_{i+1}\boldsymbol{w}_i/\rho_i+\boldsymbol{w}_{i+1}=\boldsymbol{v}_{i+1}$，即

$$\boldsymbol{w}_1=\boldsymbol{v}_1,\qquad \boldsymbol{w}_{k+1}=\boldsymbol{v}_{k+1}-\frac{\theta_{k+1}}{\rho_k}\boldsymbol{w}_k.$$

小问题的解是 $\boldsymbol{y}_k=\boldsymbol{R}_k^{-1}(\phi_1,\dots,\phi_k)^{\top}$，于是 $\boldsymbol{x}_k=\sum_{i\le k}(\phi_i/\rho_i)\boldsymbol{w}_i$，已确定的 ϕ_i 此后不变，回代化为逐步累加 $\boldsymbol{x}_k=\boldsymbol{x}_{k-1}+(\phi_k/\rho_k)\boldsymbol{w}_k$。

这一短递推与完整的小问题回代给出同一个 $\boldsymbol{x}_k$，却只保存一个方向。变换后右端的末分量 $|\bar\phi_{k+1}|$ 就是原残差长度，提供了不必形成残差的停止估计；有限精度下它会偏离真实值，仍须直接重算原残差和正规残差来核验。

12.9.2 算法实现

初始化 LSQR 的输入是一般的实矩阵 $\boldsymbol{A}$ 与 $\boldsymbol{b}$，允许秩亏，输出为 $\boldsymbol{x}$。超参数是阈值和步数上限 K：以最小二乘为目标时，用正规残差的绝对阈值 $\tau_n\ge 0$；以相容方程为目标时，另用第 11.7节的 atol, rtol。初值固定为 $\boldsymbol{x}_0=\boldsymbol{0}$。若 $K=0$，直接输出 $\boldsymbol{x}_0$；否则先按第 12.8节的起步检查零右端与已满足正规方程的情形，并按第 12.12节检查初值。初值的原残差是 $\boldsymbol{b}$，正规残差 $\boldsymbol{A}^{\top}\boldsymbol{b}$ 的长度是 $\alpha_1\beta_1$，这一检查与双对角化的起步共用同一次 $\boldsymbol{A}^{\top}$ 乘法。初值已满足条件或起步给出零解时输出 $\boldsymbol{x}_0$，否则取

$$\boldsymbol{w}_1=\boldsymbol{v}_1,\qquad \bar\rho_1=\alpha_1,\qquad \bar\phi_1=\beta_1.$$

这里 $\bar\rho_1$ 是小问题第一列尚未变换的对角元，$\bar\phi_1$ 是右端 $\beta_1\boldsymbol{e}_1$ 的第一个分量，$\boldsymbol{w}_1$ 是第一个更新方向。

双对角化与正交变换 第 k 轮先做一次双对角化，得到 β_{k+1},α_{k+1} 及存在的 $\boldsymbol{u}_{k+1},\boldsymbol{v}_{k+1}$；扩张停止时跳过不存在的新基，本轮的变换照常完成。然后按主要思想中的公式依次计算

$$\rho_k=\sqrt{\bar\rho_k^2+\beta_{k+1}^2},\qquad c_k=\frac{\bar\rho_k}{\rho_k},\qquad s_k=\frac{\beta_{k+1}}{\rho_k},$$
$$\theta_{k+1}=s_k\alpha_{k+1},\qquad \bar\rho_{k+1}=-c_k\alpha_{k+1},$$
$$\phi_k=c_k\bar\phi_k,\qquad \bar\phi_{k+1}=s_k\bar\phi_k.$$

其中 ρ_k 与 θ_{k+1} 是上双对角因子 $\boldsymbol{R}_k$ 的新对角元和上对角元，ϕ_k 是变换后右端的第 k 个分量，$\bar\rho_{k+1}$ 与 $\bar\phi_{k+1}$ 留给下一轮。

更新解与停止 变换完成后，用当前方向更新解：

$$\boldsymbol{x}_k = \boldsymbol{x}_{k-1} + \frac{\phi_k}{\rho_k}\boldsymbol{w}_k.$$

这时原残差与正规残差的长度可以直接从标量读出，分别为 $|\bar{\phi}_{k+1}|$ 和 $|\bar{\phi}_{k+1}|\alpha_{k+1}|c_k|$。若相应的估计达到第 12.12节的阈值，或已达到 K，就按该节复核后输出 $\boldsymbol{x}_k$；否则取下一方向 $\boldsymbol{w}_{k+1} = \boldsymbol{v}_{k+1} - (\theta_{k+1}/\rho_k)\boldsymbol{w}_k$，进入下一轮。$\boldsymbol{w}_{k+1}$ 排在 $\boldsymbol{x}_k$ 之后计算，因为两者都要用旧的 $\boldsymbol{w}_k$。

零系数与异常 双对角化出现零系数时，本轮的变换和解更新照常完成，之后不再生成下一方向，直接计算 $\boldsymbol{r} = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_k$ 与 $\boldsymbol{A}^{\top}\boldsymbol{r}$，按相容方程或一般最小二乘分别验收：$\beta_{k+1} = 0$ 使 $s_k = 0$，原残差估计为零；$\alpha_{k+1} = 0$ 使正规残差估计为零。正常步骤中 $\rho_k > 0$：$\bar{\rho}_1 = \alpha_1 > 0$，而只要继续迭代就有 $\alpha_{k+1} > 0$，归纳可知各 $\bar{\rho}_k \neq 0$，所以 $\rho_k \geq |\bar{\rho}_k| > 0$。出现零 ρ_k、明显失去正交性、到达迭代上限或残差长期不降时，分别报告不同的原因，不把残差估计当成无需复核的精确值。

示例 12.18 直线拟合上的 LSQR 沿用示例 12.15的系数。初始化取 $\boldsymbol{w}_1 = \boldsymbol{v}_1$、$\bar{\rho}_1 = \alpha_1 \approx 2.6034$、$\bar{\phi}_1 = 3$。第一轮的变换由 $(\bar{\rho}_1, \beta_2) \approx (2.6034, 0.5944)$ 得 $\rho_1 \approx 2.6704$、$c_1 \approx 0.9749$、$s_1 \approx 0.2226$；作用于新列和右端，得 $\theta_2 \approx 0.1658$、$\bar{\rho}_2 \approx -0.7259$、$\phi_1 \approx 2.9247$、$\bar{\phi}_2 \approx 0.6678$。更新解得

$$\boldsymbol{x}_1 = \frac{\phi_1}{\rho_1}\boldsymbol{w}_1 = \frac{61}{435}(5,6)^{\top} \approx (0.7011, 0.8414)^{\top},$$

它是沿 $\boldsymbol{A}^{\top}\boldsymbol{b} = (5,6)^{\top}$ 方向使残差最小的点。两个估计 $|\bar{\phi}_2| \approx 0.6678$ 和 $|\bar{\phi}_2|\alpha_2|c_1| \approx 0.4848$ 与直接计算的 $\|\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_1\|_2 = \sqrt{194/435}$ 和 $\|\boldsymbol{A}^{\top}(\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_1)\|_2$ 一致。

由于 $\alpha_3 = 0$，第二轮完成变换和更新后结束：$\rho_2 \approx 0.9173$、$\phi_2 \approx -0.5285$，$\boldsymbol{w}_2 = \boldsymbol{v}_2 - (\theta_2/\rho_1)\boldsymbol{w}_1 \approx (-0.8080, 0.5925)^{\top}$，$\boldsymbol{x}_2 = \boldsymbol{x}_1 + (\phi_2/\rho_2)\boldsymbol{w}_2 = (7/6, 1/2)^{\top}$，正是最小二乘解 $\hat{\boldsymbol{x}}$；原残差估计 $|\bar{\phi}_3| \approx 0.4082 = 1/\sqrt{6}$ 等于最优残差 $(-1/6, 1/3, -1/6)^{\top}$ 的长度，正规残差估计为零。

示例 12.19 不相容矩形系统上的 LSQR 沿用示例 12.16的系数，初始化 $\bar{\rho}_1 = \alpha_1 = \sqrt{5/3}$、$\bar{\phi}_1 = \sqrt{3}$。第一轮 $\rho_1 = \sqrt{\alpha_1^2 + \beta_2^2} = \sqrt{17/5} \approx$

1.8439, $c_1 = 5/\sqrt{51}$, $s_1 = \sqrt{26/51}$, 于是 $\theta_2 = 6/\sqrt{85}$、$\bar\rho_2 = -\sqrt{90/221}$、$\phi_1 = 5/\sqrt{17}$、$\bar\phi_2 = \sqrt{26/17}$。更新得

$$\boldsymbol{x}_1 = \frac{\phi_1}{\rho_1}\boldsymbol{v}_1 = \frac{5}{17}(1,2)^{\mathsf T}.$$

直接计算 $\boldsymbol{r}_1 = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_1 = (12/17, -3/17, 1)^{\mathsf T}$，长度 $\sqrt{26/17} = |\bar\phi_2|$；正规残差 $\boldsymbol{A}^{\mathsf T}\boldsymbol{r}_1 = (12/17, -6/17)^{\mathsf T}$，长度约 0.7892，与 $|\bar\phi_2|\alpha_2|c_1|$ 一致。

第二轮保留第一轮的方向与标量：$\rho_2 = \sqrt{\bar\rho_2^2 + \beta_3^2} = \sqrt{20/17} \approx 1.084652289$，$c_2 = -3/\sqrt{26}$，$\phi_2 = c_2\bar\phi_2 = -3/\sqrt{17} \approx -0.727606875$，$\bar\phi_3 = 1$；由于 $\alpha_3 = 0$，$\theta_3 = \bar\rho_3 = 0$。方向 $\boldsymbol{w}_2 = \boldsymbol{v}_2 - (\theta_2/\rho_1)\boldsymbol{w}_1 = \boldsymbol{v}_2 - \frac{6}{17}\boldsymbol{v}_1 = (-40, 5)^{\mathsf T}/(17\sqrt{5})$，于是

$$\boldsymbol{x}_2 = \boldsymbol{x}_1 + \frac{\phi_2}{\rho_2}\boldsymbol{w}_2 = \Big(1, \frac{1}{2}\Big)^{\mathsf T}.$$

这时 $\boldsymbol{r}_2 = (0,0,1)^{\mathsf T}$，$\boldsymbol{A}^{\mathsf T}\boldsymbol{r}_2 = \boldsymbol{0}$：最小二乘已经完成，原残差停在不可拟合的长度 $1 = |\bar\phi_3|$ 上。独立复核：小问题 $\min\|\beta_1\boldsymbol{e}_1 - \boldsymbol{B}_2\boldsymbol{y}\|_2$ 的正规方程是 $\boldsymbol{B}_2^{\mathsf T}\boldsymbol{B}_2\boldsymbol{y} = \alpha_1\beta_1\boldsymbol{e}_1$，解出的 $\boldsymbol{V}_2\boldsymbol{y}$ 同样是 $(1, 1/2)^{\mathsf T}$。

12.9.3 算法分析

正确性 先说明递推确实解出了小问题(12.4)。

定理 12.20 LSQR 递推的正确性 在精确算术中，设双对角化在第 k 轮之前没有终止。则按上述递推得到的 $\boldsymbol{x}_k$ 等于 $\boldsymbol{V}_k\boldsymbol{y}_k$，其中 $\boldsymbol{y}_k$ 是小问题(12.4)的解，即 $\boldsymbol{x}_k$ 是 $\mathrm{range}(\boldsymbol{V}_k)$ 中使 $\|\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}\|_2$ 最小的点；并且

$$\|\boldsymbol{r}_k\|_2 = |\bar\phi_{k+1}|, \qquad \|\boldsymbol{A}^{\mathsf T}\boldsymbol{r}_k\|_2 = |\bar\phi_{k+1}|\,\alpha_{k+1}|c_k|.$$

证明 记前 k 次正交变换之积为 $\boldsymbol{Q}_k$。每轮的新列只在第 k、$k+1$ 行非零，此前的变换都不触及它的第 $k+1$ 行，所以一次新变换就能延续三角化，归纳得到

$$\boldsymbol{Q}_k\begin{bmatrix}\boldsymbol{B}_k & \beta_1\boldsymbol{e}_1\end{bmatrix} = \begin{bmatrix}\boldsymbol{R}_k & \boldsymbol{f}_k \\ \boldsymbol{0}^{\mathsf T} & \bar\phi_{k+1}\end{bmatrix},$$

其中 $\boldsymbol{R}_k$ 上双对角，对角元为 $\rho_1, \dots, \rho_k$，上对角元为 $\theta_2, \dots, \theta_k$，$\boldsymbol{f}_k = (\phi_1, \dots, \phi_k)^{\mathsf T}$。$\boldsymbol{Q}_k$ 正交，所以 $\|\beta_1\boldsymbol{e}_1 - \boldsymbol{B}_k\boldsymbol{y}\|_2^2 = \|\boldsymbol{f}_k - \boldsymbol{R}_k\boldsymbol{y}\|_2^2 + \bar\phi_{k+1}^2$，最

小点是 $\boldsymbol{y}_k = \boldsymbol{R}_k^{-1}\boldsymbol{f}_k$，最小残差 $|\bar{\phi}_{k+1}|$ 就是 $\|\boldsymbol{r}_k\|_2$。主要思想中已由 $(\boldsymbol{V}_k\boldsymbol{R}_k^{-1})\boldsymbol{R}_k = \boldsymbol{V}_k$ 逐列推出方向递推；$\boldsymbol{R}_k$ 和 $\boldsymbol{f}_k$ 在后续轮次中不再改动，回代因此化为逐步累加 $\boldsymbol{x}_k = \boldsymbol{x}_{k-1} + \phi_k \boldsymbol{w}_k/\rho_k$。正规残差估计来自(12.3)的第二式：小问题的残差 $\boldsymbol{g}_k = \beta_1\boldsymbol{e}_1 - \boldsymbol{B}_k\boldsymbol{y}_k$ 满足 $\boldsymbol{B}_k^{\top}\boldsymbol{g}_k = \boldsymbol{0}$，所以 $\boldsymbol{A}^{\top}\boldsymbol{r}_k = \alpha_{k+1}(\boldsymbol{e}_{k+1}^{\top}\boldsymbol{g}_k)\boldsymbol{v}_{k+1}$；而 $\boldsymbol{g}_k = \boldsymbol{Q}_k^{\top}(\boldsymbol{0}, \bar{\phi}_{k+1})^{\top}$，只有最后一次变换触及第 $k+1$ 个分量，得 $\boldsymbol{e}_{k+1}^{\top}\boldsymbol{g}_k = -c_k\bar{\phi}_{k+1}$。 ■

残差的单调性与选出的解 由此可以读出 LSQR 的几条性质。候选空间逐轮嵌套，所以精确算术中原残差不增；正规残差没有这样的保证，可能某一步上升。每个 $\boldsymbol{v}_i$ 都由 $\boldsymbol{A}^{\top}$ 作用后再作组合得到，零初值使各步近似都留在 $\mathrm{range}(\boldsymbol{A}^{\top})$ 中。一旦达到正规方程，$\boldsymbol{x}_k$ 就是与 $\mathrm{null}(\boldsymbol{A})$ 正交的最小二乘解，即第 9.4节的 $\boldsymbol{A}^{\dagger}\boldsymbol{b}$；$\alpha_{k+1} = 0$ 正是这种情形。

与正规方程上 CG 的关系 LSQR 与正规方程上的 CG 还有下面的等价关系。

定理 12.21 LSQR 与正规方程上的 CG 在精确算术中，只要两种方法都尚未终止，LSQR 的第 k 步近似就等于对正规方程 $\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{x} = \boldsymbol{A}^{\top}\boldsymbol{b}$ 从 $\boldsymbol{x}_0 = \boldsymbol{0}$ 施行第 12.2节 CG 的第 k 步近似。

证明 记 $\hat{\boldsymbol{x}} = \boldsymbol{A}^{\dagger}\boldsymbol{b}$，$\hat{\boldsymbol{r}} = \boldsymbol{b} - \boldsymbol{A}\hat{\boldsymbol{x}}$。CG 的各步都在 $\mathcal{K}_k(\boldsymbol{A}^{\top}\boldsymbol{A}, \boldsymbol{A}^{\top}\boldsymbol{b}) \subseteq \mathrm{range}(\boldsymbol{A}^{\top})$ 中，$\boldsymbol{A}^{\top}\boldsymbol{A}$ 在这个子空间上正定，所以 CG 的第 k 步是该 Krylov 空间中使 $\|\boldsymbol{x} - \hat{\boldsymbol{x}}\|_{\boldsymbol{A}^{\top}\boldsymbol{A}}^2 = \|\boldsymbol{A}(\boldsymbol{x} - \hat{\boldsymbol{x}})\|_2^2$ 最小的点。另一方面，$\hat{\boldsymbol{r}}$ 与 $\mathrm{range}(\boldsymbol{A})$ 正交，由勾股定理

$$\|\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}\|_2^2 = \|\hat{\boldsymbol{r}}\|_2^2 + \|\boldsymbol{A}(\boldsymbol{x} - \hat{\boldsymbol{x}})\|_2^2,$$

右边第一项与 $\boldsymbol{x}$ 无关。由定理 12.17，两种方法的候选空间都是 $\mathrm{range}(\boldsymbol{V}_k)$，最小化的又是同一个函数；$\boldsymbol{A}$ 在 $\mathrm{range}(\boldsymbol{A}^{\top})$ 上是单射，最小点唯一，所以两者相等。 ■

收敛速度与数值敏感度 由这一等价，CG 的收敛界可以直接搬到 LSQR：迭代面对的是 $\boldsymbol{A}^{\top}\boldsymbol{A}$，收敛快慢由 $\boldsymbol{A}$ 的非零奇异值的平方的分布决定。$\boldsymbol{A}$ 满列秩时，$\kappa_2(\boldsymbol{A}^{\top}\boldsymbol{A}) = \kappa_2(\boldsymbol{A})^2$，CG 界中的 $\sqrt{\kappa}$ 正好是 $\kappa_2(\boldsymbol{A})$，于是 $\|\boldsymbol{A}(\boldsymbol{x}_k - \hat{\boldsymbol{x}})\|_2 \le 2\big((\kappa_2(\boldsymbol{A}) - 1)/(\kappa_2(\boldsymbol{A}) + 1)\big)^k \|\boldsymbol{A}\hat{\boldsymbol{x}}\|_2$。

LSQR 不形成 Gram 矩阵，避免了第 10.6节在形成 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 时丢失信息，但这并不消除原问题的病态性：$\kappa_2(\boldsymbol{A})$ 很大时上式的因子仍接近 1，问题对数

据的敏感度也不因算法改变。有限精度下基的正交性和两个残差估计都会偏离精确值，仍须按第 12.12节复核。

计算代价 每轮的核心工作是一次 $\boldsymbol{A}$ 乘向量和一次 $\boldsymbol{A}^{\mathsf{T}}$ 乘向量，另加十几次标量运算、一次正交变换和两次长度为 d 的向量更新；需要保存的是 $\boldsymbol{u}$ 和 $\boldsymbol{v},\boldsymbol{w},\boldsymbol{x}$，工作存储为 $O(m+d)$。对相容方程，LSQR 也能求解，但每轮多一次转置作用，是否比方阵专用的方法划算，要结合矩阵结构与精度目标比较。

12.10 LSMR 算法

12.10.1 主要思想

LSMR 由 Fong 与 Saunders 提出[3]。它与 LSQR 在同一个子空间 $\operatorname{range}(\boldsymbol{V}_k)$ 中取点，但改为最小化正规残差 $\|\boldsymbol{A}^{\mathsf{T}}(\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x})\|_2$，这正是判断是否到达最小二乘解所看的量。用 $\boldsymbol{A}^{\mathsf{T}}$ 左乘原残差的表示 $\boldsymbol{U}_{k+1}(\beta_1\boldsymbol{e}_1-\boldsymbol{B}_k\boldsymbol{y})$，由(12.3)的第二式及 $\boldsymbol{B}_k^{\mathsf{T}}\boldsymbol{e}_1=\alpha_1\boldsymbol{e}_1$、$\boldsymbol{e}_{k+1}^{\mathsf{T}}\boldsymbol{B}_k=\beta_{k+1}\boldsymbol{e}_k^{\mathsf{T}}$，得到

$$\begin{aligned}\boldsymbol{A}^{\mathsf{T}}(\boldsymbol{b}-\boldsymbol{A}\boldsymbol{V}_k\boldsymbol{y}) &= \boldsymbol{V}_{k+1}(\alpha_1\beta_1\boldsymbol{e}_1-\boldsymbol{C}_k\boldsymbol{y}),\\ \boldsymbol{C}_k &= \begin{bmatrix}\boldsymbol{B}_k^{\mathsf{T}}\boldsymbol{B}_k\\ \alpha_{k+1}\beta_{k+1}\boldsymbol{e}_k^{\mathsf{T}}\end{bmatrix}.\end{aligned}\tag{12.5}$$

$\boldsymbol{V}_{k+1}$ 的列标准正交，所以第 k 步求解小问题 $\min_{\boldsymbol{y}}\|\alpha_1\beta_1\boldsymbol{e}_1-\boldsymbol{C}_k\boldsymbol{y}\|_2$，区别于 LSQR 最小化原残差。若 $\alpha_{k+1}=0$，$\boldsymbol{C}_k$ 的最后一行为零，删去它并只用已有的 $\boldsymbol{V}_k$ 表达，不假定存在额外的右基向量。

实际计算不形成 $\boldsymbol{B}_k^{\mathsf{T}}\boldsymbol{B}_k$，否则又回到了 Gram 矩阵。先用 LSQR 的第一组正交变换把 $\boldsymbol{B}_k$ 三角化为上双对角的 $\boldsymbol{R}_k$，则 $\boldsymbol{B}_k^{\mathsf{T}}\boldsymbol{B}_k=\boldsymbol{R}_k^{\mathsf{T}}\boldsymbol{R}_k$。令 $\boldsymbol{t}=\boldsymbol{R}_k\boldsymbol{y}$；$\boldsymbol{R}_k^{-1}$ 是上三角矩阵，末行只有对角元 $1/\rho_k$，所以 $\boldsymbol{e}_k^{\mathsf{T}}\boldsymbol{y}=\boldsymbol{e}_k^{\mathsf{T}}\boldsymbol{R}_k^{-1}\boldsymbol{t}=t_k/\rho_k$。小问题于是改写为

$$\min_{\boldsymbol{t}}\left\|\alpha_1\beta_1\boldsymbol{e}_1-\begin{bmatrix}\boldsymbol{R}_k^{\mathsf{T}}\\ \theta_{k+1}\boldsymbol{e}_k^{\mathsf{T}}\end{bmatrix}\boldsymbol{t}\right\|_2,\qquad \theta_{k+1}=\frac{\alpha_{k+1}\beta_{k+1}}{\rho_k},$$

这里的 θ_{k+1} 与第一组变换给出的 $s_k\alpha_{k+1}$ 相同。

增广矩阵是下双对角的，形状与 $\boldsymbol{B}_k$ 一样，所以可以像 LSQR 那样再作一组正交变换，把它化为上双对角的 $\bar{\boldsymbol{R}}_k$（对角元 $\bar\rho_i$，上对角元 $\bar\theta_{i+1}$），右端化为 $\boldsymbol{z}_k=(\zeta_1,\dots,\zeta_k)^{\mathsf{T}}$ 与末分量 $\bar\zeta_{k+1}$。于是依次解 $\bar{\boldsymbol{R}}_k\boldsymbol{t}=\boldsymbol{z}_k$ 与 $\boldsymbol{R}_k\boldsymbol{y}=\boldsymbol{t}$，两组变换都只更新小矩阵的边界项，无需形成 $\boldsymbol{A}^{\mathsf{T}}\boldsymbol{A}$。

[3] D. C.-L. Fong, M. Saunders, *LSMR: An Iterative Algorithm for Sparse Least-Squares Problems* In SIAM Journal on Scientific Computing, 2011, vol. 33, no. 5, pp. 2950–2971

两次三角求解对应两层方向。定义 $\boldsymbol{W}_k\boldsymbol{R}_k = \boldsymbol{V}_k$ 与 $\bar{\boldsymbol{W}}_k\bar{\boldsymbol{R}}_k = \boldsymbol{W}_k$，逐列展开得

$$\boldsymbol{w}_k = \frac{\boldsymbol{v}_k - \theta_k \boldsymbol{w}_{k-1}}{\rho_k}, \qquad \bar{\boldsymbol{w}}_k = \frac{\boldsymbol{w}_k - \bar{\theta}_k \bar{\boldsymbol{w}}_{k-1}}{\bar{\rho}_k}, \qquad \boldsymbol{x}_k = \boldsymbol{x}_{k-1} + \zeta_k \bar{\boldsymbol{w}}_k,$$

因为 $\boldsymbol{x}_k = \boldsymbol{V}_k\boldsymbol{R}_k^{-1}\bar{\boldsymbol{R}}_k^{-1}\boldsymbol{z}_k = \bar{\boldsymbol{W}}_k\boldsymbol{z}_k$，而 $\boldsymbol{z}_k$ 已确定的分量此后不变。ρ, θ 与 $\bar{\rho}, \bar{\theta}$ 分别是两组三角因子的对角元和上副对角元。

12.10.2 算法实现

初始化 输入、超参数、零初值和输出的约定都与 LSQR 相同。先按第 12.8节的起步检查零右端与已满足正规方程的情形，零解直接输出；否则取

$$\boldsymbol{x}_0 = \boldsymbol{0}, \qquad \boldsymbol{w}_0 = \bar{\boldsymbol{w}}_0 = \boldsymbol{0}, \qquad \theta_1 = 0,$$
$$\bar{\alpha}_1 = \alpha_1, \qquad \bar{\zeta}_1 = \alpha_1\beta_1, \qquad \bar{c}_0 = 1, \qquad \bar{s}_0 = 0.$$

$\bar{\zeta}_1 = \|\boldsymbol{A}^{\mathsf{T}}\boldsymbol{b}\|_2$ 是初始正规残差的长度；$\bar{\alpha}_1$ 相当于 LSQR 中的 $\bar{\rho}_1$，改名是为了把带横线的 ρ 留给第二组变换。其余几个量只是占位，使第一轮的公式不必单独处理：$\theta_1 = 0$ 与 $\boldsymbol{w}_0 = \boldsymbol{0}$ 使 $\boldsymbol{w}_1 = \boldsymbol{v}_1/\rho_1$，$\bar{s}_0 = 0$ 使第一轮的 $\bar{\theta}_1 = 0$。这里采用未缩放的方向，使它们与两次三角回代直接对应。

第一组旋转 第 k 轮先完成一次双对角化，再作第一组旋转。本节使用第 12.4节的旋转约定 $\left[\begin{smallmatrix} c & s \\ -s & c \end{smallmatrix}\right]$，它把 $\boldsymbol{B}_k$ 化为与 LSQR 相同的上双对角因子 $\boldsymbol{R}_k$，只是 $\bar{\alpha}_{k+1}$ 与 LSQR 的 $\bar{\rho}_{k+1}$ 差一个符号：

$$\rho_k = \sqrt{\bar{\alpha}_k^2 + \beta_{k+1}^2}, \qquad c_k = \frac{\bar{\alpha}_k}{\rho_k}, \qquad s_k = \frac{\beta_{k+1}}{\rho_k},$$
$$\theta_{k+1} = s_k\alpha_{k+1}, \qquad \bar{\alpha}_{k+1} = c_k\alpha_{k+1}.$$

第二组旋转 接着作第二组旋转。它处理的是对角元为 ρ_i、下对角元为 θ_{i+1} 的下双对角矩阵，新列在第 k、$k+1$ 行上的元素是 ρ_k, θ_{k+1}。上一轮的旋转 $(\bar{c}_{k-1}, \bar{s}_{k-1})$ 先作用于这一列的第 $k-1$、k 行，在第 $k-1$ 行产生 $\bar{\theta}_k$，在第 k 行留下 $\bar{c}_{k-1}\rho_k$；本轮旋转再消去它下方的 θ_{k+1}，并把右端分量 $\bar{\zeta}_k$ 分成 ζ_k 与留给下一轮的 $\bar{\zeta}_{k+1}$：

$$\bar{\theta}_k = \bar{s}_{k-1}\rho_k, \qquad \bar{\rho}_k = \sqrt{(\bar{c}_{k-1}\rho_k)^2 + \theta_{k+1}^2},$$
$$\bar{c}_k = \frac{\bar{c}_{k-1}\rho_k}{\bar{\rho}_k}, \qquad \bar{s}_k = \frac{\theta_{k+1}}{\bar{\rho}_k},$$
$$\zeta_k = \bar{c}_k\bar{\zeta}_k, \qquad \bar{\zeta}_{k+1} = -\bar{s}_k\bar{\zeta}_k.$$

第二组旋转用到本轮的 ρ_k, θ_{k+1}，所以排在第一组之后。

更新方向与解 两组旋转完成后，按主要思想中的两条方向公式先计算 $\boldsymbol{w}_k$、再计算 $\bar{\boldsymbol{w}}_k$，最后更新解：

$$\boldsymbol{w}_k = \frac{\boldsymbol{v}_k - \theta_k \boldsymbol{w}_{k-1}}{\rho_k}, \qquad \bar{\boldsymbol{w}}_k = \frac{\boldsymbol{w}_k - \bar{\theta}_k \bar{\boldsymbol{w}}_{k-1}}{\bar{\rho}_k}, \qquad \boldsymbol{x}_k = \boldsymbol{x}_{k-1} + \zeta_k \bar{\boldsymbol{w}}_k.$$

$\boldsymbol{w}_k$ 的公式用上一轮保存的 θ_k，本轮算出的 θ_{k+1} 留给下一轮；保存 $\boldsymbol{w}_k, \bar{\boldsymbol{w}}_k$ 及下一轮所需的标量即可。

停止与零系数 $|\bar{\zeta}_{k+1}|$ 是当前正规残差长度的估计。以最小二乘为目标时，它达到第 12.12节的阈值或已达到 K，就按该节复核后输出 $\boldsymbol{x}_k$；以相容方程为目标时，递推不直接给出原残差，在候选终止处由 $\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_k$ 计算。双对角化出现零系数时，本轮的两组旋转和解更新照常完成，然后验收并停止扩张：$\alpha_{k+1} = 0$（含 $\beta_{k+1} = 0$ 时的约定）使 $\theta_{k+1} = 0$、$\bar{s}_k = 0$，于是 $\bar{\zeta}_{k+1} = 0$。正常步骤中 $\rho_k, \bar{\rho}_k$ 都为正，理由与 LSQR 中的 ρ_k 相同；任何零分母都须在相除前检查。

与缩放方向的关系 文献中的算法常用缩放后的方向 $\boldsymbol{h}_k = \rho_k \boldsymbol{w}_k$ 与 $\bar{\boldsymbol{h}}_k = \rho_k \bar{\rho}_k \bar{\boldsymbol{w}}_k$。代入上面的公式，得到等价的形式

$$\bar{\boldsymbol{h}}_k = \boldsymbol{h}_k - \frac{\bar{\theta}_k \rho_k}{\rho_{k-1} \bar{\rho}_{k-1}} \bar{\boldsymbol{h}}_{k-1}, \qquad \boldsymbol{x}_k = \boldsymbol{x}_{k-1} + \frac{\zeta_k}{\rho_k \bar{\rho}_k} \bar{\boldsymbol{h}}_k, \qquad \boldsymbol{h}_{k+1} = \boldsymbol{v}_{k+1} - \frac{\theta_{k+1}}{\rho_k} \boldsymbol{h}_k,$$

其中 $\boldsymbol{h}_1 = \boldsymbol{v}_1$，并约定 $\rho_0 = \bar{\rho}_0 = 1$、$\bar{\boldsymbol{h}}_0 = \boldsymbol{0}$。两种写法的乘法次数相同，选用哪一种只影响需要保存的标量。

示例 12.22 不相容矩形系统上的 LSMR 沿用示例 12.16的系数，与例 12.19对照。初始化 $\bar{\alpha}_1 = \sqrt{5/3}$，$\bar{\zeta}_1 = \alpha_1 \beta_1 = \sqrt{5}$。第一组旋转与 LSQR 相同，$\rho_1 = \sqrt{17/5} \approx 1.843908891$，$\theta_2 = 6/\sqrt{85} \approx 0.650791373$。第二组旋转中 $\bar{\theta}_1 = 0$，$\bar{\rho}_1 = \sqrt{\rho_1^2 + \theta_2^2} = \sqrt{65/17} \approx 1.955384722$，$\bar{c}_1 = 17/(5\sqrt{13})$，$\bar{s}_1 = 6/(5\sqrt{13})$，于是 $\zeta_1 = 17/\sqrt{65} \approx 2.108590488$，$\bar{\zeta}_2 = -6/\sqrt{65}$。方向 $\boldsymbol{w}_1 = \boldsymbol{v}_1/\rho_1$，$\bar{\boldsymbol{w}}_1 = \boldsymbol{w}_1/\bar{\rho}_1$，得

$$\boldsymbol{x}_1 = \zeta_1 \bar{\boldsymbol{w}}_1 = \frac{17}{65}(1, 2)^{\mathsf{T}}.$$

这一步的正规残差为 $\boldsymbol{A}^{\mathsf{T}}(\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_1) = (48/65, -6/65)^{\mathsf{T}}$，长度 $6/\sqrt{65} \approx 0.7442 = |\bar{\zeta}_2|$，小于 LSQR 第一步的 $\|(12/17, -6/17)^{\mathsf{T}}\|_2 \approx 0.7892$；反过来，原残差长度约 1.2440，大于 LSQR 的 $\sqrt{26/17} \approx 1.2367$。两种方法在同一个一维空间中取点，只因优化的对象不同而选出不同的点。独立核验：$k = 1$ 时 $\boldsymbol{C}_1 = (17/5, 6/5)^{\mathsf{T}}$，小问题 $\min_y \|(\sqrt{5}, 0)^{\mathsf{T}} - \boldsymbol{C}_1 y\|_2$ 的解是 $y = 17\sqrt{5}/65$，$y\boldsymbol{v}_1$ 与上式相同。

第二轮的第一组旋转给出 $\rho_2 = \sqrt{20/17}$、$c_2 = 3/\sqrt{26}$，又因 $\alpha_3 = 0$ 而 $\theta_3 = 0$。第二组旋转得 $\bar\theta_2 = \bar s_1\rho_2 \approx 0.3610$，$\bar\rho_2 = \bar c_1\rho_2 \approx 1.0228$，$\bar c_2 = 1$，$\bar s_2 = 0$，故 $\zeta_2 = \bar\zeta_2 = -6/\sqrt{65}$，$\bar\zeta_3 = 0$。方向 $\boldsymbol{w}_2 = (\boldsymbol{v}_2 - \theta_2\boldsymbol{w}_1)/\rho_2 = (-4, 1/2)^{\top}/\sqrt{17}$，再由 $\bar{\boldsymbol{w}}_2 = (\boldsymbol{w}_2 - \bar\theta_2\bar{\boldsymbol{w}}_1)/\bar\rho_2$ 更新，得到 $\boldsymbol{x}_2 = (1, 1/2)^{\top}$，$\boldsymbol{r}_2 = (0, 0, 1)^{\top}$，$\boldsymbol{A}^{\top}\boldsymbol{r}_2 = \boldsymbol{0}$。$k = 2$ 时 $\boldsymbol{C}_2$ 的末行为零，删去后小问题就是 $\boldsymbol{B}_2^{\top}\boldsymbol{B}_2\boldsymbol{y} = \alpha_1\beta_1\boldsymbol{e}_1$，与例 12.19最后的复核相同；这一小规模对照可以用来检查旋转符号、下标与旧量的读取顺序。

12.10.3 算法分析

正确性 两组旋转对应两层三角分解，由此可以把 LSMR 的最优性与它和 MINRES 的关系一并写出。

定理 12.23 LSMR 的最小正规残差性及与 MINRES 的等价 在精确算术中，设双对角化在第 k 轮之前没有终止。则 LSMR 递推得到的 $\boldsymbol{x}_k$ 是 $\operatorname{range}(\boldsymbol{V}_k) = \mathcal{K}_k(\boldsymbol{A}^{\top}\boldsymbol{A}, \boldsymbol{A}^{\top}\boldsymbol{b})$ 中使正规残差 $\|\boldsymbol{A}^{\top}(\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x})\|_2$ 最小的唯一点，最小值为 $|\bar\zeta_{k+1}|$；它也等于对正规方程 $\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{x} = \boldsymbol{A}^{\top}\boldsymbol{b}$ 从 $\boldsymbol{x}_0 = \boldsymbol{0}$ 施行第 12.5节 MINRES 的第 k 步近似，即该 Krylov 空间中使 $\|\boldsymbol{A}^{\top}\boldsymbol{b} - \boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{x}\|_2$ 最小的点。

证明 由(12.5)及 $\boldsymbol{V}_{k+1}$ 的列标准正交，$\boldsymbol{x} = \boldsymbol{V}_k\boldsymbol{y}$ 的正规残差长度等于 $\|\alpha_1\beta_1\boldsymbol{e}_1 - \boldsymbol{C}_k\boldsymbol{y}\|_2$，只需说明递推解出了这个小问题。第一组旋转给出 $\boldsymbol{B}_k = \boldsymbol{Q}_k^{\top}[\boldsymbol{R}_k; \boldsymbol{0}^{\top}]$，所以 $\boldsymbol{B}_k^{\top}\boldsymbol{B}_k = \boldsymbol{R}_k^{\top}\boldsymbol{R}_k$；又 $\theta_{k+1}\rho_k = \alpha_{k+1}\beta_{k+1}$，而 $\boldsymbol{R}_k$ 的末行是 $\rho_k\boldsymbol{e}_k^{\top}$，于是

$$\boldsymbol{C}_k = \begin{bmatrix} \boldsymbol{R}_k^{\top} \\ \theta_{k+1}\boldsymbol{e}_k^{\top} \end{bmatrix} \boldsymbol{R}_k .$$

左边的因子是下双对角的，形状与 $\boldsymbol{B}_k$ 相同。$\boldsymbol{R}_k$ 的对角元 ρ_i 都为正，换元 $\boldsymbol{t} = \boldsymbol{R}_k\boldsymbol{y}$ 是可逆的；第二组旋转像 LSQR 一样把左边的因子化为上双对角因子 $\bar{\boldsymbol{R}}_k$（对角元 $\bar\rho_i$，上对角元 $\bar\theta_{i+1}$）和右端 $\boldsymbol{z}_k = (\zeta_1, \dots, \zeta_k)^{\top}$，最小残差为 $|\bar\zeta_{k+1}|$。因此

$$\boldsymbol{x}_k = \boldsymbol{V}_k\boldsymbol{R}_k^{-1}\bar{\boldsymbol{R}}_k^{-1}\boldsymbol{z}_k .$$

$\boldsymbol{V}_k\boldsymbol{R}_k^{-1} = \boldsymbol{W}_k$ 的第 i 列是 $\boldsymbol{w}_i$，再右乘 $\bar{\boldsymbol{R}}_k^{-1}$ 得到 $\bar{\boldsymbol{W}}_k$，逐列比较即得两条方向递推，而 $\boldsymbol{z}_k$ 的分量此后不再改变，所以解按 $\boldsymbol{x}_k = \boldsymbol{x}_{k-1} + \zeta_k\bar{\boldsymbol{w}}_k$ 累加。

最小点唯一，是因为 $\mathrm{range}(\boldsymbol{V}_k) \subseteq \mathrm{range}(\boldsymbol{A}^{\top})$，而 $\mathrm{null}(\boldsymbol{A}^{\top}\boldsymbol{A}) = \mathrm{null}(\boldsymbol{A})$ 与 $\mathrm{range}(\boldsymbol{A}^{\top})$ 正交，$\boldsymbol{x} \mapsto \boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{x}$ 在这个子空间上是单射。由定理 12.17，该子空间就是 $\mathcal{K}_k(\boldsymbol{A}^{\top}\boldsymbol{A}, \boldsymbol{A}^{\top}\boldsymbol{b})$。对称矩阵 $\boldsymbol{A}^{\top}\boldsymbol{A}$、右端 $\boldsymbol{A}^{\top}\boldsymbol{b}$ 与零初值下，MINRES 在同一个 Krylov 空间中最小化同一个函数 $\|\boldsymbol{A}^{\top}\boldsymbol{b} - \boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{x}\|_2$，所以两者的第 k 步相同。 ■

残差的单调性 候选空间逐轮嵌套，所以精确算术中正规残差不增。原残差同样不增。记同一步 LSQR 与 LSMR 的近似为 $\boldsymbol{x}_k^{\mathrm{Q}}$ 与 $\boldsymbol{x}_k^{\mathrm{M}}$，可以证明后者是截至当前步各 LSQR 近似的凸组合，$\boldsymbol{x}_{k+1}^{\mathrm{M}}$ 又是 $\boldsymbol{x}_k^{\mathrm{M}}$ 与 $\boldsymbol{x}_{k+1}^{\mathrm{Q}}$ 的凸组合，而 $\|\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}\|_2^2$ 是凸函数，且 $\boldsymbol{x}_{k+1}^{\mathrm{Q}}$ 在包含 $\boldsymbol{x}_k^{\mathrm{M}}$ 的空间中使它最小。正规残差单调下降，使 LSMR 在不相容问题上按 τ_n 停止时更平稳；原残差则是 LSQR 每步最小，例 12.22的第一步正好显示了这一对照。

选出的解与收敛速度 零初值使各步留在 $\mathrm{range}(\boldsymbol{A}^{\top})$ 中，与 LSQR 的论证相同，达到正规方程时选出 $\boldsymbol{A}^{\dagger}\boldsymbol{b}$。由定理 12.23，在行空间上 LSMR 等价于正规方程上的 MINRES，速度同样受非零奇异值平方的分布控制。小奇异值与正交性损失仍然影响精度；两个残差单调，并不推出解的误差也单调，有限精度下仍需用真实残差复核。

计算代价 每轮的核心工作仍是一次 $\boldsymbol{A}$ 乘向量和一次 $\boldsymbol{A}^{\top}$ 乘向量。与 LSQR 相比，LSMR 多一组标量旋转和一套方向 $\bar{\boldsymbol{w}}_k$ 的更新，需要保存 $\boldsymbol{u}$ 和 $\boldsymbol{v}, \boldsymbol{w}, \bar{\boldsymbol{w}}, \boldsymbol{x}$，工作存储仍为 $O(m + d)$。

12.11 预条件

12.11.1 主要思想

前面各方法的收敛快慢由系数矩阵的谱或奇异值分布决定。**预条件**（preconditioning）选一个固定的可逆矩阵 $\boldsymbol{M}$，它在某种意义上接近 $\boldsymbol{A}$，而 $\boldsymbol{M}\boldsymbol{z} = \boldsymbol{r}$ 又容易求解；把方程改写成以 $\boldsymbol{M}^{-1}\boldsymbol{A}$ 或 $\boldsymbol{A}\boldsymbol{M}^{-1}$ 为系数的等价方程，迭代面对的就是更集中的谱分布，所需步数随之减少。实现时不显式求 $\boldsymbol{M}^{-1}$，也不形成变换后的矩阵，每次需要时求解一次 $\boldsymbol{M}\boldsymbol{z} = \boldsymbol{r}$。

改写有两种基本方式。左预条件解 $\boldsymbol{M}^{-1}\boldsymbol{A}\boldsymbol{x} = \boldsymbol{M}^{-1}\boldsymbol{b}$，未知量不变，但迭代看到的残差是 $\boldsymbol{M}^{-1}(\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x})$；以残差为准则的方法（如 GMRES）因此最小化的是换了尺度的残差。右预条件令 $\boldsymbol{x} = \boldsymbol{M}^{-1}\boldsymbol{y}$，解 $\boldsymbol{A}\boldsymbol{M}^{-1}\boldsymbol{y} = \boldsymbol{b}$，残差仍是原残差，最后由 $\boldsymbol{y}$ 换回 $\boldsymbol{x}$。两种方式在计算上都只需要解辅助方程 $\boldsymbol{M}\boldsymbol{z} = \boldsymbol{r}$。

CG 还要求系数矩阵对称正定，而 $\boldsymbol{M}^{-1}\boldsymbol{A}$ 一般不对称，不能直接交给普通 CG。设 $\boldsymbol{A}$ 与 $\boldsymbol{M}$ 都对称正定，写 $\boldsymbol{M}=\boldsymbol{C}\boldsymbol{C}^{\top}$，作变量代换 $\boldsymbol{x}=\boldsymbol{C}^{-\top}\boldsymbol{y}$，并在方程两边左乘 $\boldsymbol{C}^{-1}$，得到

$$\widehat{\boldsymbol{A}}\boldsymbol{y}=\boldsymbol{C}^{-1}\boldsymbol{b},\qquad \widehat{\boldsymbol{A}}=\boldsymbol{C}^{-1}\boldsymbol{A}\boldsymbol{C}^{-\top},$$

$\widehat{\boldsymbol{A}}$ 对称正定，可以施行 CG。

把变换后 CG 的量换回原变量，就得到可以直接执行的公式。变换后的残差与方向对应 $\hat{\boldsymbol{r}}=\boldsymbol{C}^{-1}\boldsymbol{r}$、$\hat{\boldsymbol{p}}=\boldsymbol{C}^{\top}\boldsymbol{p}$，记 $\boldsymbol{z}=\boldsymbol{M}^{-1}\boldsymbol{r}$ 与配对量 $\tau=\boldsymbol{r}^{\top}\boldsymbol{z}$。逐项换算，$\hat{\boldsymbol{r}}^{\top}\hat{\boldsymbol{r}}=\boldsymbol{r}^{\top}\boldsymbol{C}^{-\top}\boldsymbol{C}^{-1}\boldsymbol{r}=\boldsymbol{r}^{\top}\boldsymbol{M}^{-1}\boldsymbol{r}=\tau$，$\hat{\boldsymbol{p}}^{\top}\widehat{\boldsymbol{A}}\hat{\boldsymbol{p}}=\boldsymbol{p}^{\top}\boldsymbol{A}\boldsymbol{p}$，所以 CG 的两个内积比变成

$$\alpha_k=\frac{\tau_k}{\boldsymbol{p}_k^{\top}\boldsymbol{A}\boldsymbol{p}_k},\qquad \beta_k=\frac{\tau_{k+1}}{\tau_k}.$$

方向递推 $\hat{\boldsymbol{p}}_{k+1}=\hat{\boldsymbol{r}}_{k+1}+\beta_k\hat{\boldsymbol{p}}_k$ 两边左乘 $\boldsymbol{C}^{-\top}$，得 $\boldsymbol{p}_{k+1}=\boldsymbol{M}^{-1}\boldsymbol{r}_{k+1}+\beta_k\boldsymbol{p}_k=\boldsymbol{z}_{k+1}+\beta_k\boldsymbol{p}_k$。整个过程只用到 $\boldsymbol{M}$ 的求解，$\boldsymbol{C}$ 只在推导中出现。

常用的预条件有三类。对角预条件取 $\boldsymbol{M}=\operatorname{diag}(\boldsymbol{A})$，一次应用只是逐分量相除。SSOR 预条件直接复用第 11.6节的分裂矩阵：$\boldsymbol{A}$ 对称正定且 $0<\omega<2$ 时它对称正定，一次应用是一次前代、一次对角缩放和一次回代。**不完全分解**（incomplete factorization）沿用第 10章 LU 或 Cholesky 的消元公式，但只在预先给定的稀疏模式上保留元素，舍弃消元产生的新增填充；保留的位置越多，因子越接近完整分解，构造与应用的代价也越高。

预条件还须保持所用方法的前提。对 PCG 选用不完全 Cholesky 时，每一列开方前的量都须为正，这一点不像完整 Cholesky 那样由 $\boldsymbol{A}$ 正定自动保证，需要逐个检查；普通的不完全 LU 或一般的左、右预条件并不自动给出对称正定的 $\boldsymbol{M}$，不满足 PCG 的要求。对最小二乘问题，还须单独确认变换是否改变了残差的权重和最小范数的选解，这在算法分析中讨论。

12.11.2 算法实现

预条件的应用　预条件 $\boldsymbol{M}$ 是超参数，输入仍为 $\boldsymbol{A},\boldsymbol{b}$，输出仍为 $\boldsymbol{x}$。对角缩放要求对角元非零，一次应用执行 $z_i=r_i/a_{i,i}$。SSOR 预条件写 $\boldsymbol{A}=\boldsymbol{D}+\boldsymbol{L}+\boldsymbol{L}^{\top}$，其中 $\boldsymbol{D}$ 为对角部分、$\boldsymbol{L}$ 为严格下三角部分，取

$$\boldsymbol{M}=\frac{1}{\omega(2-\omega)}(\boldsymbol{D}+\omega\boldsymbol{L})\boldsymbol{D}^{-1}(\boldsymbol{D}+\omega\boldsymbol{L}^{\top}),\qquad 0<\omega<2;$$

一次应用按第 11.6节的顺序，先前代解 $(\boldsymbol{D}+\omega\boldsymbol{L})\boldsymbol{y}=\boldsymbol{r}$，再形成 $\omega(2-\omega)\boldsymbol{D}\boldsymbol{y}$，最后回代解 $(\boldsymbol{D}+\omega\boldsymbol{L}^{\top})\boldsymbol{z}=\omega(2-\omega)\boldsymbol{D}\boldsymbol{y}$。

不完全分解的构造　不完全分解先固定保留模式 $\mathcal{S}$，常用的是 $\boldsymbol{A}$ 自身的非零位置。不完全 Cholesky 按第 10.2节的列公式(10.5)逐列计算，但只计算

$(i,j)\in\mathcal{S}$ 的 $l_{i,j}$，模式外的元素一律置零，后续求和也只用保留下来的元素。不完全 LU 在第 10.1节的消元中，只更新 $(i,j)\in\mathcal{S}$ 的 $w_{i,j}$，把落在模式外的填充丢弃；为保持预先给定的模式，这里通常不选主元。所得因子保存下来，每次应用做两次稀疏三角求解，即第 10.1节的前代(10.2)与回代(10.3)。若构造中出现零主元或非正的开方量，就报告构造失败，或采用事先说明的修正方案，例如给对角加一个正移位后重新构造。

示例 12.24　一个不完全 Cholesky 分解　取对称正定矩阵 $\boldsymbol{A}=\left[\begin{smallmatrix}4&1&1\\1&4&0\\1&0&4\end{smallmatrix}\right]$，保留模式取 $\boldsymbol{A}$ 下三角的非零位置，即 $(1,1),(2,1),(3,1),(2,2),(3,3)$。按列公式得 $l_{1,1}=2$，$l_{2,1}=l_{3,1}=1/2$，$l_{2,2}=\sqrt{4-1/4}=\sqrt{15}/2$。完整 Cholesky 在 $(3,2)$ 处会产生填充 $l_{3,2}=(0-l_{3,1}l_{2,1})/l_{2,2}=-1/(2\sqrt{15})$，它不在模式中，于是置零；随后 $l_{3,3}=\sqrt{4-1/4}=\sqrt{15}/2$。所得 $\boldsymbol{M}=\boldsymbol{L}\boldsymbol{L}^{\top}$ 与 $\boldsymbol{A}$ 只在 $(2,3),(3,2)$ 两处不同，那里的元素是 $l_{2,1}l_{3,1}=1/4$ 而不是 0。$\boldsymbol{M}$ 对称正定，因子与 $\boldsymbol{A}$ 同样稀疏，一次应用只需两次稀疏三角求解。

PCG 的初始化　下面以**预条件共轭梯度法**（preconditioned conjugate gradient method，PCG）为例写出完整步骤。要求 $\boldsymbol{A}$ 与 $\boldsymbol{M}$ 都对称正定，超参数为 $\boldsymbol{x}_0,\mathrm{atol},\mathrm{rtol},K$ 和 $\boldsymbol{M}$；本小节的 α_k,β_k 是 CG 的步长与组合系数，与双对角化的系数无关。初始化时计算 $\boldsymbol{r}_0=\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_0$，并按第 11.7节作停止检查，已达到原残差容差则直接输出；未结束时求解 $\boldsymbol{M}\boldsymbol{z}_0=\boldsymbol{r}_0$，取 $\tau_0=\boldsymbol{r}_0^{\top}\boldsymbol{z}_0$、$\boldsymbol{p}_0=\boldsymbol{z}_0$。

PCG 的每轮更新　第 k 轮先计算

$$\boldsymbol{q}_k=\boldsymbol{A}\boldsymbol{p}_k,\qquad \alpha_k=\frac{\tau_k}{\boldsymbol{p}_k^{\top}\boldsymbol{q}_k},$$

$$\boldsymbol{x}_{k+1}=\boldsymbol{x}_k+\alpha_k\boldsymbol{p}_k,\qquad \boldsymbol{r}_{k+1}=\boldsymbol{r}_k-\alpha_k\boldsymbol{q}_k,$$

然后按第 11.7节检查原残差，满足阈值或达到 K 时输出 $\boldsymbol{x}$。未结束时求解 $\boldsymbol{M}\boldsymbol{z}_{k+1}=\boldsymbol{r}_{k+1}$，再取

$$\tau_{k+1}=\boldsymbol{r}_{k+1}^{\top}\boldsymbol{z}_{k+1},\qquad \beta_k=\frac{\tau_{k+1}}{\tau_k},\qquad \boldsymbol{p}_{k+1}=\boldsymbol{z}_{k+1}+\beta_k\boldsymbol{p}_k.$$

与 CG 相比，只是新方向由预条件残差 $\boldsymbol{z}$ 而不是 $\boldsymbol{r}$ 组合而成，内积 $\boldsymbol{r}^{\top}\boldsymbol{r}$ 换成 $\boldsymbol{r}^{\top}\boldsymbol{z}$。$\boldsymbol{A}$ 与 $\boldsymbol{M}$ 正定保证正常步骤的两个分母为正；残差为零时已先结束。若未收敛时出现非正的 τ_k 或 $\boldsymbol{p}_k^{\top}\boldsymbol{q}_k$，应检查 $\boldsymbol{A},\boldsymbol{M}$ 的正定前提与数值状态，而不是继续迭代。

其他方法中的预条件 其他方法不必另写完整算法，只需替换系数矩阵的作用。右预条件求解 $\boldsymbol{A}\boldsymbol{M}^{-1}\boldsymbol{y}=\boldsymbol{b}$，再令 $\boldsymbol{x}=\boldsymbol{M}^{-1}\boldsymbol{y}$：例如 GMRES 每次需要 $\boldsymbol{A}\boldsymbol{M}^{-1}\boldsymbol{v}$ 时，先解 $\boldsymbol{M}\boldsymbol{z}=\boldsymbol{v}$ 再乘 $\boldsymbol{A}$。对 LSQR 和 LSMR，两种方法都把 $\boldsymbol{A}\boldsymbol{v}$ 换成 $\boldsymbol{A}(\boldsymbol{M}^{-1}\boldsymbol{v})$，把 $\boldsymbol{A}^{\top}\boldsymbol{u}$ 换成 $\boldsymbol{M}^{-\top}(\boldsymbol{A}^{\top}\boldsymbol{u})$，结束时由 $\boldsymbol{y}$ 换回 $\boldsymbol{x}$。

示例 12.25 贯穿例上的 PCG 对示例 11.1 的 $\boldsymbol{A},\boldsymbol{b}$ 与 $\boldsymbol{x}_0=\boldsymbol{0}$，取对角缩放 $\boldsymbol{M}=\operatorname{diag}(4,3)$。初始化得 $\boldsymbol{r}_0=(1,2)^{\top}$，$\boldsymbol{z}_0=\boldsymbol{M}^{-1}\boldsymbol{r}_0=(1/4,2/3)^{\top}$，$\tau_0=\boldsymbol{r}_0^{\top}\boldsymbol{z}_0=19/12$，$\boldsymbol{p}_0=\boldsymbol{z}_0$。第一轮，$\boldsymbol{q}_0=\boldsymbol{A}\boldsymbol{p}_0=(5/3,9/4)^{\top}$，$\boldsymbol{p}_0^{\top}\boldsymbol{q}_0=23/12$，$\alpha_0=19/23$，于是

$$\boldsymbol{x}_1=\Big(\frac{19}{92},\frac{38}{69}\Big)^{\top}\approx(0.2065,0.5507)^{\top},\qquad \boldsymbol{r}_1=\Big(-\frac{26}{69},\frac{13}{92}\Big)^{\top},$$

直接计算 $\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_1$ 得到同一残差。CG 最小化的误差 $\|\boldsymbol{x}-\boldsymbol{x}_\star\|_{\boldsymbol{A}}$ 从初值处的 $\sqrt{15/11}\approx1.168$ 降到约 0.236；同一初值下普通 CG 的第一步是 $(1/4,1/2)^{\top}$，这一误差约为 0.337。再继续一轮，

$$\boldsymbol{z}_1=\Big(-\frac{13}{138},\frac{13}{276}\Big)^{\top},\qquad \beta_0=\frac{\tau_1}{\tau_0}=\frac{169}{6348},\qquad \alpha_1=\frac{276}{209},$$

得到 $\boldsymbol{x}_2=(1/11,7/11)^{\top}=\boldsymbol{x}_\star$，原残差为零，与二维问题至多两步结束一致。

按工作量记录：对角预条件的构造只是读出两个对角元；两轮共做了两次辅助求解（$\boldsymbol{z}_0,\boldsymbol{z}_1$）和两次矩阵乘向量（$\boldsymbol{q}_0,\boldsymbol{q}_1$），复核残差另计。普通 CG 在这个问题上也是两步结束，所以本例只用来核对公式，不能据此声称预条件普遍减少步数；预条件的收益要看下面的谱分析与总工作量。

12.11.3 算法分析

正确性 PCG 的正确性来自主要思想中那个保持对称的变换。下面的定理把那里的推导写成归纳，说明 PCG 就是对 $\widehat{\boldsymbol{A}}$ 施行 CG 后换回原变量。

定理 12.26 PCG 与变换后 CG 的等价 设 $\boldsymbol{A},\boldsymbol{M}$ 对称正定，$\boldsymbol{M}=\boldsymbol{C}\boldsymbol{C}^{\top}$，$\widehat{\boldsymbol{A}}=\boldsymbol{C}^{-1}\boldsymbol{A}\boldsymbol{C}^{-\top}$。在精确算术中，只要 PCG 尚未终止，它的迭代量与对 $\widehat{\boldsymbol{A}}\boldsymbol{y}=\boldsymbol{C}^{-1}\boldsymbol{b}$ 从 $\boldsymbol{y}_0=\boldsymbol{C}^{\top}\boldsymbol{x}_0$ 施行 CG 所得的迭代量满足

$$\boldsymbol{y}_k=\boldsymbol{C}^{\top}\boldsymbol{x}_k,\qquad \hat{\boldsymbol{r}}_k=\boldsymbol{C}^{-1}\boldsymbol{r}_k,\qquad \hat{\boldsymbol{p}}_k=\boldsymbol{C}^{\top}\boldsymbol{p}_k.$$

因此 $\boldsymbol{x}_k$ 是 $\boldsymbol{x}_0+\mathcal{K}_k(\boldsymbol{M}^{-1}\boldsymbol{A},\boldsymbol{M}^{-1}\boldsymbol{r}_0)$ 中使 $\|\boldsymbol{x}-\boldsymbol{x}_\star\|_{\boldsymbol{A}}$ 最小的唯一点，并且

$$\|\boldsymbol{x}_k-\boldsymbol{x}_\star\|_{\boldsymbol{A}} \le 2\Big(\frac{\sqrt{\hat\kappa}-1}{\sqrt{\hat\kappa}+1}\Big)^k \|\boldsymbol{x}_0-\boldsymbol{x}_\star\|_{\boldsymbol{A}},$$

$$\hat\kappa=\kappa_2(\widehat{\boldsymbol{A}})=\frac{\lambda_{\max}(\boldsymbol{M}^{-1}\boldsymbol{A})}{\lambda_{\min}(\boldsymbol{M}^{-1}\boldsymbol{A})}.$$

证明 对 k 归纳。$k=0$ 时，$\hat{\boldsymbol{r}}_0=\boldsymbol{C}^{-1}\boldsymbol{b}-\widehat{\boldsymbol{A}}\boldsymbol{C}^{\top}\boldsymbol{x}_0=\boldsymbol{C}^{-1}\boldsymbol{r}_0$，$\hat{\boldsymbol{p}}_0=\hat{\boldsymbol{r}}_0=\boldsymbol{C}^{\top}(\boldsymbol{C}^{-\top}\boldsymbol{C}^{-1}\boldsymbol{r}_0)=\boldsymbol{C}^{\top}\boldsymbol{z}_0=\boldsymbol{C}^{\top}\boldsymbol{p}_0$。设第 k 步对应关系成立，则

$$\hat{\boldsymbol{r}}_k^{\top}\hat{\boldsymbol{r}}_k=\boldsymbol{r}_k^{\top}\boldsymbol{M}^{-1}\boldsymbol{r}_k=\boldsymbol{r}_k^{\top}\boldsymbol{z}_k,\qquad \hat{\boldsymbol{p}}_k^{\top}\widehat{\boldsymbol{A}}\hat{\boldsymbol{p}}_k=\boldsymbol{p}_k^{\top}\boldsymbol{A}\boldsymbol{p}_k,$$

两种方法的步长相同，于是 $\boldsymbol{y}_{k+1}=\boldsymbol{C}^{\top}\boldsymbol{x}_{k+1}$，$\hat{\boldsymbol{r}}_{k+1}=\boldsymbol{C}^{-1}(\boldsymbol{r}_k-\alpha_k\boldsymbol{A}\boldsymbol{p}_k)=\boldsymbol{C}^{-1}\boldsymbol{r}_{k+1}$；组合系数同为 τ_{k+1}/τ_k，故 $\hat{\boldsymbol{p}}_{k+1}=\boldsymbol{C}^{-1}\boldsymbol{r}_{k+1}+\beta_k\boldsymbol{C}^{\top}\boldsymbol{p}_k=\boldsymbol{C}^{\top}(\boldsymbol{z}_{k+1}+\beta_k\boldsymbol{p}_k)=\boldsymbol{C}^{\top}\boldsymbol{p}_{k+1}$。

由定理 12.3，$\boldsymbol{y}_k$ 是 $\boldsymbol{y}_0+\mathcal{K}_k(\widehat{\boldsymbol{A}},\hat{\boldsymbol{r}}_0)$ 中使 $\|\boldsymbol{y}-\boldsymbol{C}^{\top}\boldsymbol{x}_\star\|_{\widehat{\boldsymbol{A}}}$ 最小的唯一点。换回 $\boldsymbol{x}=\boldsymbol{C}^{-\top}\boldsymbol{y}$ 时，$\|\boldsymbol{C}^{\top}(\boldsymbol{x}-\boldsymbol{x}_\star)\|_{\widehat{\boldsymbol{A}}}=\|\boldsymbol{x}-\boldsymbol{x}_\star\|_{\boldsymbol{A}}$，且 $\boldsymbol{C}^{-\top}\widehat{\boldsymbol{A}}^{j}\hat{\boldsymbol{r}}_0=(\boldsymbol{M}^{-1}\boldsymbol{A})^{j}\boldsymbol{M}^{-1}\boldsymbol{r}_0$，所以仿射子空间和目标都对应过来，收敛界也随之成立。最后，$\boldsymbol{M}^{-1}\boldsymbol{A}=\boldsymbol{C}^{-\top}\widehat{\boldsymbol{A}}\boldsymbol{C}^{\top}$ 与 $\widehat{\boldsymbol{A}}$ 相似，而 $\widehat{\boldsymbol{A}}$ 对称正定，$\kappa_2(\widehat{\boldsymbol{A}})$ 就是特征值之比。 ■

$\boldsymbol{M}^{-1}\boldsymbol{A}$ 本身一般不对称，不能直接交给普通 CG；定理中的 $\boldsymbol{C}$ 只用于论证，算法只需求解 $\boldsymbol{M}\boldsymbol{z}=\boldsymbol{r}$。论证要求整个迭代使用同一个固定的线性作用 $\boldsymbol{M}^{-1}$；预条件随轮次变化时，标准 PCG 的共轭性与最优性不再沿用。

收敛速度 定理把速度归结为 $\boldsymbol{M}^{-1}\boldsymbol{A}$ 的特征值分布。对角缩放适合各行各列尺度相差很大的矩阵。例如取 $d=10,\boldsymbol{A}=\boldsymbol{S}\boldsymbol{T}\boldsymbol{S},$ 其中 $\boldsymbol{S}=\mathrm{diag}(1,2,\dots,10)$，$\boldsymbol{T}$ 是对角元为 1、次对角元为 0.4 的三对角矩阵。$\boldsymbol{A}$ 的对角部分是 $\boldsymbol{S}^2$，取 $\boldsymbol{M}=\boldsymbol{S}^2$ 与 $\boldsymbol{C}=\boldsymbol{S}$，变换后恰好 $\widehat{\boldsymbol{A}}=\boldsymbol{T}$，特征值为 $1+0.8\cos(j\pi/11)$，$j=1,\dots,10$。

图 12.4比较两组特征值：$\boldsymbol{A}$ 的特征值从约 0.73 铺到约 133，比值约 182.7；缩放后全部落在 $[0.23,1.77]$ 内，比值约 7.61。定理中的收缩因子相应从约 0.862 降到约 0.468，而每轮只多一次逐项除法。

计算代价 每轮比 CG 多一次 $\boldsymbol{M}$ 求解，选用时要同时计入构造 $\boldsymbol{M}$ 与每轮应用的成本，比较达到同一精度的总工作量。对角缩放几乎不需构造；SSOR 不需额外存储因子，但每次应用相当于两次三角扫掠；不完全分解要先付出构造代价并存储因子，换来通常更接近 $\boldsymbol{A}$ 的近似。

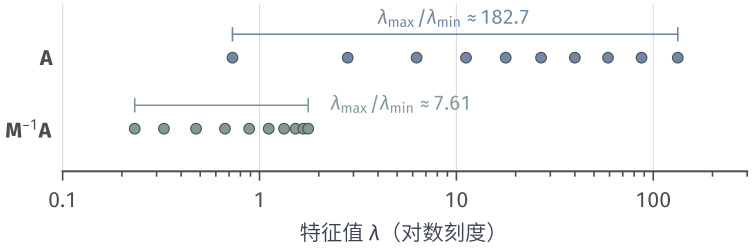


图 12.4 对角缩放前后的特征值分布（对数横轴）。矩阵为 $\boldsymbol{A}=\boldsymbol{STS}$，$\boldsymbol{S}=\mathrm{diag}(1,\dots,10)$，$\boldsymbol{T}$ 为对角元 1、次对角元 0.4 的三对角矩阵，预条件 $\boldsymbol{M}=\mathrm{diag}(\boldsymbol{A})$。蓝点为 $\boldsymbol{A}$ 的 10 个特征值（数值计算），绿点为 $\boldsymbol{M}^{-1}\boldsymbol{A}$ 的特征值 $1+0.8\cos(j\pi/11)$；括线标出各自的范围与最大、最小特征值之比。

GMRES 与 MINRES 的预条件 对 GMRES，左预条件在预条件后的 Krylov 空间中最小化 $\|\boldsymbol{M}^{-1}(\boldsymbol{b}-\boldsymbol{Ax})\|_2$，右预条件保留原残差 $\|\boldsymbol{b}-\boldsymbol{Ax}\|_2$ 作为目标；两者结束时都回到第 11.7节检查原残差。MINRES 要求保持对称性，只能采用对称正定预条件 $\boldsymbol{M}=\boldsymbol{CC}^{\mathsf{T}}$ 的分裂变换 $\boldsymbol{C}^{-1}\boldsymbol{AC}^{-\mathsf{T}}$。预条件只改善变换后的谱，不改变原问题对数据的敏感度。

最小二乘目标的保持 对不相容最小二乘问题，还要核对变换是否保持原目标。左变换给出 $\|\boldsymbol{M}^{-1}(\boldsymbol{b}-\boldsymbol{Ax})\|_2^2=(\boldsymbol{b}-\boldsymbol{Ax})^{\mathsf{T}}\boldsymbol{M}^{-\mathsf{T}}\boldsymbol{M}^{-1}(\boldsymbol{b}-\boldsymbol{Ax})$，即第 9.5节以 $\boldsymbol{M}^{-\mathsf{T}}\boldsymbol{M}^{-1}$ 为权的加权目标，一般会改变解。可逆右变换 $\boldsymbol{x}=\boldsymbol{M}^{-1}\boldsymbol{y}$ 使两个问题的残差逐点相同，原残差目标和解集都保留；但零初值在 $\boldsymbol{y}$ 坐标下选出的是 $\|\boldsymbol{y}\|_2=\|\boldsymbol{Mx}\|_2$ 最小的解，秩亏时它未必是原坐标下欧氏范数最小的最小二乘解。因此比较预条件时不能只比较迭代次数，还要确认所求的是不是原来那个解。

12.12 收敛检验与停止准则

方阵上的 CG、PCG、GMRES、MINRES、BiCG 与 BiCGSTAB 统一沿用第 11.7节的规则：超参数为 $\boldsymbol{x}_0,\mathrm{atol},\mathrm{rtol},K$，以阈值 $\mathrm{atol}+\mathrm{rtol}\|\boldsymbol{b}\|_2$ 检查真实原残差 $\|\boldsymbol{b}-\boldsymbol{Ax}_k\|_2$，达到阈值或步数上限时输出当前 $\boldsymbol{x}$。达到上限本身不表示已经收敛。

递推残差和小问题残差只用于内部计算，决定何时值得复核，不另作算法输出。它们在精确算术下等于真实残差，浮点计算中却会逐渐偏离：CG 与 PCG 的递推残差，GMRES 的 $|g_{j+1}|$，MINRES 的 $|\bar{g}_{j+1}|$，LSQR 与 LSMR 的标量估计都是如此。所以实现中定期、并在每次候选终止前，用 $\boldsymbol{A},\boldsymbol{b},\boldsymbol{x}_k$ 重新计算残差。

LSQR 与 LSMR 以相容方程为目标时，可以沿用同一原残差阈值。以最小二乘为目标时，不相容问题的最优原残差不为零，原残差阈值可能永远达不到，所以单列非负超参数 τ_n，检查

$$\|\boldsymbol{A}^{\mathsf{T}}(\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_k)\|_2 \le \tau_n,$$

允许原残差非零。原残差的大小与正规残差是否接近零回答的是两个不同的问题：前者说明数据被拟合得多好，后者说明是否已经到达最小二乘解。τ_n 是绝对阈值，应与所用数据的尺度相配，不除以 $\|\boldsymbol{A}^{\mathsf{T}}\boldsymbol{b}\|_2$ 这类可能为零的参照量。初值已满足条件时直接输出 $\boldsymbol{x}_0=\boldsymbol{0}$；其余情况在每次候选终止和最终输出前都复核。达到 K 时只输出当前 $\boldsymbol{x}$，残差和停止原因都不纳入输出。

没有达到精度而结束的情形要彼此区分。步数上限只说明不再继续计算；停滞指真实残差在若干轮内几乎不降，常见于重启 GMRES；中断指 BiCG、BiCGSTAB 的配对量或 ω 为零，或 PCG 遇到非正的分母，这时递推本身无法继续。它们都不能报告成收敛，后续是调整参数、换用预条件还是换用方法，要根据具体原因决定。

残差小的含义还要结合原问题的条件数来解释；要求最小范数解时，还须保持零初值、迭代留在行空间，并核对预条件下的选解准则。真实残差复核所需的矩阵乘法计入实际成本。误差的解释留到第 14.1节，达到同一精度的综合比较留到第 14.3节。

12.13 本章小结

本章从定常迭代每轮丢弃历史信息这一缺点出发，把初始残差及其矩阵乘积张成的 Krylov 子空间保留下来，在逐步扩大的仿射空间 $\boldsymbol{x}_0+\mathcal{K}_k$ 中选取近似。选一个近似等价于选一个在原点取值 1 的残差多项式；各方法的区别在于按什么准则选这个多项式，以及怎样用性质良好的基而不是病态的幂向量完成计算。由于系数随当前向量变化，收敛性都由各自的选解准则推出，而不是由固定误差矩阵的谱半径判断。

方阵上的方法按矩阵结构分工。对称正定矩阵用 CG，它在当前子空间中最小化误差的能量范数，步长与组合系数都可由残差长度算出，短递推在精确算术下保持全部正交与共轭关系，误差界由 $\sqrt{\kappa_2(\boldsymbol{A})}$ 控制。一般方阵用 Arnoldi 正交化得到 Hessenberg 关系，GMRES 在其上最小化原残差，残差单调不增，但基的存储与正交化工作随步数增长；重启限制了存储，也失去了跨周期的最优性，可能停滞。对称不定矩阵用 MINRES，Lanczos 三项递推与带状 QR 使它在固定存储下仍最小化原残差，收敛界只依赖特征值。

非对称矩阵若要固定存储，就要放弃残差最小化。BiCG 用原矩阵与转置矩阵维持双正交和双共轭，系数公式与 CG 同形，但残差可能波动，配对量为零时递推中断。BiCGSTAB 用固定影子向量代替影子序列，方向的组合系数由残差多项式的首项系数比推出，再加一次局部最小残差步；每轮只用 $\boldsymbol{A}$，局部改进只相对于中间残差成立，既不保证整轮单调，也不消除中断。

长方或秩亏的问题由 Golub–Kahan 双对角化处理：交替作用 $\boldsymbol{A}$ 与 $\boldsymbol{A}^{\top}$，在两个空间各得一组标准正交基，右侧基张成 $\mathcal{K}_k(\boldsymbol{A}^{\top}\boldsymbol{A}, \boldsymbol{A}^{\top}\boldsymbol{b})$，却从不形成 $\boldsymbol{A}^{\top}\boldsymbol{A}$。LSQR 在其中最小化原残差，精确算术下等价于正规方程上的 CG；LSMR 最小化正规残差，等价于正规方程上的 MINRES，需要两层正交变换和两套方向。两者都取零初值，到达正规方程时选出最小范数解 $\boldsymbol{A}^{\dagger}\boldsymbol{b}$；它们避免了形成 Gram 矩阵时的信息损失，但收敛快慢仍由非零奇异值平方的分布决定，原问题的病态性也不因算法而消失。

预条件用一个易解的 $\boldsymbol{M}$ 改变迭代面对的谱：对角缩放、SSOR 与不完全分解分别复用前几章的公式，PCG 则是对称正定变换系统上的 CG，换回原变量后只需每轮多解一次 $\boldsymbol{M}\boldsymbol{z} = \boldsymbol{r}$。选用时要同时计入构造与应用的代价，并核对变换是否保持了方法的前提和原来的求解目标：PCG 与 MINRES 需要对称正定的 $\boldsymbol{M}$，左预条件会改变残差的度量，右预条件在秩亏时可能改变最小范数的选解。

最后，所有方法都以真实残差决定是否成功：方阵问题检查原残差，不相容最小二乘问题检查正规残差而允许原残差非零。递推得到的残差估计只是复核的提示；达到步数上限、停滞和中断都要与达到精度区分开。残差小到什么程度才说明解可信，取决于问题的条件数，这一问题以及在同一目标下怎样比较本章与前几章的方法，留给第 14章。

第 13 章

行列投影迭代法

第 11章的定常迭代和第 12章的 Krylov 方法，每轮都要用到整个矩阵，至少作一次矩阵乘向量。有些问题的数据却只方便逐行读取：观测按行陆续到达，或者矩阵太大，只能每次取出其中一行。这时自然的想法是每次只让一个方程成立，用一系列局部修正逐步逼近解。本章研究这种做法能求出什么解、何时收敛，以及方程不相容时应当怎样修改。

第 13.1节的 Kaczmarz 算法把当前解投影到所选方程的解超平面上，适用于相容方程；零初值时，它收敛到第 9章的最小范数解。方程不相容时，各行没有公共解，单纯的行投影不会停在最小二乘解上。第 13.2节的扩展 Kaczmarz 算法再用列投影估计右端中无法拟合的部分，把问题改写成相容方程后继续作行投影。第 13.3节说明两种算法分别用什么条件判断结果。

两种算法的推导都只用到超平面上的最短修正，即第 3.5.4节的正交投影；收敛分析用到伪逆、行空间与零空间的正交分解，以及第 5章中谱范数与最小正奇异值的刻画。本章 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$ 不必是方阵，两种算法都以 $\boldsymbol{A}, \boldsymbol{b}$ 为输入、以 $\boldsymbol{x}$ 为输出，投影中的残差和辅助向量只是内部状态。

13.1 Kaczmarz 算法

Kaczmarz 算法（Kaczmarz method）每次只读取一行，把当前解修正到满足这一行的最近点。本节先由最短修正推导更新公式，再给出循环与随机两种选行方式，最后分析它对相容方程的收敛，并说明它为什么不能直接处理不相容方程。

13.1.1 主要思想

记第 i 行为 $\boldsymbol{a}_i^{\top}$，其中 $\boldsymbol{a}_i \in \mathbb{R}^d$ 是列向量。非零行的方程 $\boldsymbol{a}_i^{\top}\boldsymbol{x} = b_i$ 的解集是以 $\boldsymbol{a}_i$ 为法向量的超平面。给定当前点 $\boldsymbol{x}_k$，要让新点 $\boldsymbol{x}_k + \boldsymbol{\delta}$ 满足这一行，就要求

$$\boldsymbol{a}_i^{\top}\boldsymbol{\delta} = b_i - \boldsymbol{a}_i^{\top}\boldsymbol{x}_k,$$

其余的行暂不考虑。满足这个条件的修正有无穷多个，取其中欧氏范数最小的一个，使新点尽量少偏离当前点。

把任意修正分为沿 $\boldsymbol{a}_i$ 的分量和与 $\boldsymbol{a}_i$ 正交的分量：$\boldsymbol{\delta} = \gamma\boldsymbol{a}_i + \boldsymbol{w}$，$\boldsymbol{a}_i^{\top}\boldsymbol{w} = 0$。行约束只涉及第一部分，给出 $\gamma\|\boldsymbol{a}_i\|_2^2 = b_i - \boldsymbol{a}_i^{\top}\boldsymbol{x}_k$；而由勾股关系，$\|\boldsymbol{\delta}\|_2^2 = \gamma^2\|\boldsymbol{a}_i\|_2^2 + \|\boldsymbol{w}\|_2^2$，在 $\boldsymbol{w} = \boldsymbol{0}$ 时最小。于是得到 Kaczmarz 更新

$$\boldsymbol{x}_{k+1} = \boldsymbol{x}_k + \frac{b_i - \boldsymbol{a}_i^{\top}\boldsymbol{x}_k}{\|\boldsymbol{a}_i\|_2^2}\,\boldsymbol{a}_i. \tag{13.1}$$

代回所选行，$\boldsymbol{a}_i^{\top}\boldsymbol{x}_{k+1} = \boldsymbol{a}_i^{\top}\boldsymbol{x}_k + (b_i - \boldsymbol{a}_i^{\top}\boldsymbol{x}_k) = b_i$，这一行精确成立。分母 $\|\boldsymbol{a}_i\|_2^2$ 来自法向量的长度，不是另外选取的步长；新点正是 $\boldsymbol{x}_k$ 到该超平面的正交投影。

方程相容时，可以任取一个精确解 $\boldsymbol{y}$ 观察距离的变化。由 $\boldsymbol{a}_i^{\top}\boldsymbol{y} = b_i$，更新可写成 $\boldsymbol{x}_{k+1} - \boldsymbol{y} = \boldsymbol{P}_i(\boldsymbol{x}_k - \boldsymbol{y})$，其中 $\boldsymbol{P}_i = \boldsymbol{I} - \boldsymbol{a}_i\boldsymbol{a}_i^{\top}/\|\boldsymbol{a}_i\|_2^2$ 是到 $\boldsymbol{a}_i^{\perp}$ 的正交投影。勾股关系给出

$$\|\boldsymbol{x}_{k+1} - \boldsymbol{y}\|_2^2 = \|\boldsymbol{x}_k - \boldsymbol{y}\|_2^2 - \frac{(b_i - \boldsymbol{a}_i^{\top}\boldsymbol{x}_k)^2}{\|\boldsymbol{a}_i\|_2^2}. \tag{13.2}$$

所以每一步到每个精确解的距离都不增，所选行的残差越大，距离减少得越多。距离减少并不意味着其他每一行的残差都减少：投影只照顾所选的一行，已经满足的行可能重新失配。

每次修正都是某个 $\boldsymbol{a}_i$ 的倍数，留在行空间 $\mathrm{range}(\boldsymbol{A}^{\top})$ 中，所以 $\boldsymbol{x}_k$ 的零空间分量始终等于初值的零空间分量。取 $\boldsymbol{x}_0 = \boldsymbol{0}$ 时，迭代始终在行空间中；若它收敛到一个精确解，这个解在行空间中，由定理 9.6，它就是最小范数解。方程不相容时没有各行共有的解 $\boldsymbol{y}$，式 (13.2)的论证不能照搬。

13.1.2 算法实现

初始化 输入为可以逐行访问的 $\boldsymbol{A}$ 和右端 $\boldsymbol{b}$，输出为 $\boldsymbol{x}$。超参数单独列出：初值 $\boldsymbol{x}_0$，选行规则，残差容差 atol, rtol，以及最大更新次数 K；要求最小范数解时取 $\boldsymbol{x}_0 = \boldsymbol{0}$。若 $\boldsymbol{A} = \boldsymbol{0}$ 且 $\boldsymbol{b} = \boldsymbol{0}$，直接返回 $\boldsymbol{x} = \boldsymbol{0}$。预先计算并保存各行的平方范数 $\|\boldsymbol{a}_i\|_2^2$。零行且 $b_i = 0$ 的方程对任何 $\boldsymbol{x}$ 成立，直接跳过；零行而 $b_i \neq 0$ 时方程 $0 = b_i$ 不可能成立，说明精确方程不相容，应报告这一点并停止，不能用式 (13.1)除以零继续。初始化计数 $k = 0$，若 $K = 0$ 则直接取 $\boldsymbol{x} = \boldsymbol{x}_0$ 并结束。

选行规则　循环版本按 $1,\dots,m$ 的固定顺序重复遍历非零行，遍历一次称为一轮扫掠。随机版本每次按概率

$$p_i = \frac{\|\boldsymbol{a}_i\|_2^2}{\|\boldsymbol{A}\|_F^2}$$

独立选取行 i_k；零行的概率为零，不会被抽到。随机版本应记录选行序列，以便复算同一条轨迹。

行投影　对所选行 $i = i_k$，先计算行残差 $s_k = b_i - \boldsymbol{a}_i^{\mathsf{T}}\boldsymbol{x}_k$，再计算修正长度 $\gamma_k = s_k / \|\boldsymbol{a}_i\|_2^2$，然后更新 $\boldsymbol{x}_{k+1} = \boldsymbol{x}_k + \gamma_k \boldsymbol{a}_i$。每完成一次行更新便把 k 加一。一次更新只读一行，不需要其他行的数据。

停止检查　达到更新次数上限时立即结束并取当前 $\boldsymbol{x}$，即使这一轮尚未扫完。在初始时和每轮完整扫掠后（随机版本则每隔预先规定的更新次数），用全部原方程计算原残差；若 $\|\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_k\|_2$ 不超过第 11.1节的阈值 $\mathrm{atol} + \mathrm{rtol}\|\boldsymbol{b}\|_2$，也结束并取当前 $\boldsymbol{x}$。所选行的行残差为零只说明这一行成立，不能作为成功退出的依据。

算例　先在第 11章的贯穿例上算两步，看清一次投影满足所选方程、却破坏另一个方程的现象；图 13.1画出了这条路径。

示例 13.1　Kaczmarz 算法的前两步　用例 11.1的方程，两行为 $\boldsymbol{a}_1 = (4,1)^{\mathsf{T}}$ 与 $\boldsymbol{a}_2 = (1,3)^{\mathsf{T}}$，平方范数分别为 17 和 10。从 $\boldsymbol{x}_0 = \boldsymbol{0}$ 出发，按 $1,2$ 的顺序投影。第一步处理第一行，行残差为 $1 - 0 = 1$，修正长度 $\gamma_0 = 1/17$，得 $\boldsymbol{x}_1 = (4/17,\, 1/17)^{\mathsf{T}}$，这时 $4x_1 + x_2 = 1$ 成立。

第二步处理第二行，行残差为 $2 - (4/17 + 3/17) = 27/17$，修正长度 $\gamma_1 = 27/170$，得 $\boldsymbol{x}_2 = (4/17, 1/17)^{\mathsf{T}} + \frac{27}{170}(1,3)^{\mathsf{T}} = (67/170,\, 91/170)^{\mathsf{T}}$。第二个方程成立了，第一个方程却又不再成立。三个点到 $\boldsymbol{x}_\star = (1/11, 7/11)^{\mathsf{T}}$ 的距离依次约为 0.643、0.595、0.320：每次投影都使近似解更接近 $\boldsymbol{x}_\star$，但两步之后还没有满足全部方程。

再取一个两行接近平行的方程，连续算两轮扫掠，逐步记录全部原方程的残差。

示例 13.2　循环 Kaczmarz 的两轮扫掠　取

$$\boldsymbol{A} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}, \qquad \boldsymbol{b} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \qquad \boldsymbol{x}_0 = \boldsymbol{0},$$

精确解为 $\boldsymbol{x}_\star=(0,1)^{\top}$，两行的平方范数为 2 和 5。第一步选第一行，行残差为 1，$\gamma_0=1/2$，得 $\boldsymbol{x}_1=(1/2,1/2)^{\top}$，全残差 $\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_1=(0,1/2)^{\top}$。

第二步选第二行，行残差为 $2-(1/2+2\cdot 1/2)=1/2$，$\gamma_1=(1/2)/5=1/10$，得 $\boldsymbol{x}_2=(3/5,7/10)^{\top}$，全残差为 $(-3/10,0)^{\top}$：第二行满足后，第一行重新失配。

第二轮先选第一行，行残差为 $-3/10$，$\gamma_2=-3/20$，得 $\boldsymbol{x}_3=(9/20,11/20)^{\top}$，全残差为 $(0,9/20)^{\top}$；再选第二行，行残差为 $9/20$，$\gamma_3=9/100$，得 $\boldsymbol{x}_4=(27/50,73/100)^{\top}$，全残差为 $(-27/100,0)^{\top}$。

每一步都有一行的残差为零，但另一行的残差始终不为零，$\boldsymbol{x}_4$ 离 $\boldsymbol{x}_\star$ 仍有约 0.604 的距离。是否停止要看每轮末全残差与容差的比较，不能把某次行残差为零当成成功。

13.1.3 算法分析

收敛性 循环版本的收敛可以由投影的几何性质直接得到。下面 $\boldsymbol{A}^{\dagger}$ 为伪逆（第 9.4节），$\boldsymbol{I}-\boldsymbol{A}^{\dagger}\boldsymbol{A}$ 是到零空间 $\ker\boldsymbol{A}$ 的正交投影。

定理 13.3 相容方程上循环 Kaczmarz 的收敛 设 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 相容且 $\boldsymbol{A}\neq\boldsymbol{0}$，令 $\boldsymbol{x}_\star=\boldsymbol{A}^{\dagger}\boldsymbol{b}+(\boldsymbol{I}-\boldsymbol{A}^{\dagger}\boldsymbol{A})\boldsymbol{x}_0$。按固定循环顺序遍历非零行时，$\boldsymbol{x}_\star$ 是方程的解，到它的距离逐步不增，且每完成一轮按与初值无关的因子 $q<1$ 几何收缩，从而 $\boldsymbol{x}_k\to\boldsymbol{x}_\star$。特别地，$\boldsymbol{x}_0=\boldsymbol{0}$ 时极限是最小范数解 $\boldsymbol{A}^{\dagger}\boldsymbol{b}$。

证明 由 $\boldsymbol{A}\boldsymbol{A}^{\dagger}\boldsymbol{b}=\boldsymbol{b}$（方程相容）与 $\boldsymbol{A}(\boldsymbol{I}-\boldsymbol{A}^{\dagger}\boldsymbol{A})=\boldsymbol{0}$，$\boldsymbol{A}\boldsymbol{x}_\star=\boldsymbol{b}$。由式 (13.2)取 $\boldsymbol{y}=\boldsymbol{x}_\star$，到 $\boldsymbol{x}_\star$ 的距离逐步不增。误差 $\boldsymbol{\varepsilon}_k=\boldsymbol{x}_k-\boldsymbol{x}_\star$ 满足 $\boldsymbol{\varepsilon}_{k+1}=\boldsymbol{P}_{i_k}\boldsymbol{\varepsilon}_k$；$\boldsymbol{\varepsilon}_0=\boldsymbol{A}^{\dagger}\boldsymbol{A}\boldsymbol{x}_0-\boldsymbol{A}^{\dagger}\boldsymbol{b}$ 在行空间中，而每个 $\boldsymbol{P}_i$ 把行空间映到自身，所以 $\boldsymbol{\varepsilon}_k$ 始终在行空间中。

一轮的误差映射是固定的 $\boldsymbol{K}=\boldsymbol{P}_{i_p}\cdots\boldsymbol{P}_{i_1}$，其中 $i_1,\dots,i_p$ 是全部非零行。若行空间中的 $\boldsymbol{v}$ 满足 $\|\boldsymbol{K}\boldsymbol{v}\|_2=\|\boldsymbol{v}\|_2$，由式 (13.2)每次投影都没有缩短长度，各次投影都不改变向量，于是 $\boldsymbol{v}$ 依次与每个非零行正交，$\boldsymbol{v}\in\ker\boldsymbol{A}\cap\operatorname{range}(\boldsymbol{A}^{\top})=\{\boldsymbol{0}\}$。取行空间的标准正交基排成 $\boldsymbol{Q}$，令 $\boldsymbol{C}=\boldsymbol{Q}^{\top}\boldsymbol{K}\boldsymbol{Q}$。由式 (5.5)，存在单位向量 $\boldsymbol{w}$ 使 $q=\|\boldsymbol{C}\|_2=\|\boldsymbol{C}\boldsymbol{w}\|_2$；$\boldsymbol{K}\boldsymbol{Q}\boldsymbol{w}$ 在行空间中，故 $\|\boldsymbol{C}\boldsymbol{w}\|_2=\|\boldsymbol{K}\boldsymbol{Q}\boldsymbol{w}\|_2<\|\boldsymbol{Q}\boldsymbol{w}\|_2=1$。于是每完成一轮，误差长度至多乘以 $q<1$，轮末误差几何地趋于零；轮内距离又不增，整个序列收敛到 $\boldsymbol{x}_\star$。 ∎

零初值使迭代始终留在行空间中，相容而解不唯一时选出最小范数解；任意初值的极限同样满足方程，但带着初值的零空间分量。

收敛速度与代价 收敛速度受各行之间的夹角和访问顺序影响：行越接近两两正交，一轮去掉的误差越多。二维时，第一步之后误差已经平行于刚投影过的直线，此后每次投影都把误差长度乘以两条直线法向夹角的余弦 $|\boldsymbol{a}_1^{\top}\boldsymbol{a}_2|/(\|\boldsymbol{a}_1\|_2\|\boldsymbol{a}_2\|_2)$。

在例 13.1中，这个余弦为 $7/\sqrt{170}\approx 0.537$，距离从 0.595 降到 0.320，比值正是这个数。例 13.2的两行接近平行，余弦为 $3/\sqrt{10}\approx 0.949$，距离依次约为 1、0.707、0.671、0.636、0.604，第一步之后每步只缩短约百分之五。两条直线越接近垂直，折线收拢得越快；越接近平行，路径就在狭窄的夹角里来回往复。

一次投影的成本为 $O(\mathrm{nnz}(\boldsymbol{a}_i))$，其中 nnz 表示非零元个数；全局残差检查另需一次完整的矩阵乘向量。

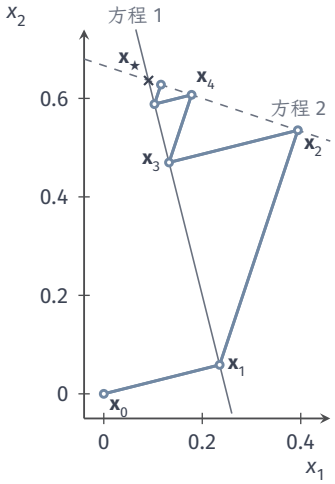


图 13.1 循环 Kaczmarz 在贯穿例上的交替投影路径。实线为第一个方程 $4x_1 + x_2 = 1$ 的解集，虚线为第二个方程 $x_1 + 3x_2 = 2$ 的解集；从 $\boldsymbol{x}_0 = \mathbf{0}$ 出发依次垂直投影到两条直线上，折线连接精确计算的前六个迭代点并逐步收拢到交点 $\boldsymbol{x}_\star$，图中标出前四个。坐标轴等比例，投影段与对应直线垂直。

随机选行 随机版本的投影公式不变，只是选行方式改为按 p_i 独立抽样，收敛结论因此是关于期望的。设方程相容，$\boldsymbol{x}_\star$ 如定理 13.3，误差 $\boldsymbol{\varepsilon}_k$ 在行空间中。在给定 $\boldsymbol{\varepsilon}_k$ 时对所选行求平均，由式 (13.2)，

$$\sum_{i=1}^{m} p_i \frac{(\boldsymbol{a}_i^{\top}\boldsymbol{\varepsilon}_k)^2}{\|\boldsymbol{a}_i\|_2^2} = \frac{\|\boldsymbol{A}\boldsymbol{\varepsilon}_k\|_2^2}{\|\boldsymbol{A}\|_F^2} \geq \frac{\sigma_r^2}{\|\boldsymbol{A}\|_F^2}\|\boldsymbol{\varepsilon}_k\|_2^2,$$

其中 σ_r 是最小正奇异值，不等号来自定理 5.4对 $\ker \boldsymbol{A}$ 正交补的下界。所以一步之后误差平方的平均至多是 $(1-\sigma_r^2/\|\boldsymbol{A}\|_F^2)\|\boldsymbol{\varepsilon}_k\|_2^2$。选取概率与行的平方范数成正比，正是为了让这一平均化成 $\|\boldsymbol{A}\boldsymbol{\varepsilon}_k\|_2^2$。

把这一步估计逐步叠加，得到 $\mathbb{E}\|\boldsymbol{\varepsilon}_k\|_2^2 \le (1-\sigma_r^2/\|\boldsymbol{A}\|_F^2)^k\|\boldsymbol{\varepsilon}_0\|_2^2$；满列秩时这一结论由 Strohmer 与 Vershynin 给出[1]。叠加时需要对此前各次选行的结果取条件期望，所用的随机变量与期望工具可参考卷七第 1 章“随机变量与概率分布”。这里的结论是期望意义下的：单条轨迹上的误差每步不增，但不保证每一步都按这个因子缩小。

[1] T. Strohmer, R. Vershynin, *A Randomized Kaczmarz Algorithm with Exponential Convergence* In Journal of Fourier Analysis and Applications, 2009, vol. 15, no. 2, pp. 262–278

不相容情形　不相容时情况不同。取 $\boldsymbol{A}=(1,1)^{\top}$，$\boldsymbol{b}=(1,3)^{\top}$，未知量是标量，两行分别要求 $x=1$ 和 $x=3$。两行长度都为一，投影化为 $x \leftarrow b_i$，循环投影便在 1 与 3 之间往返，而最小二乘解是 $\hat{x}=2$。随机选行时每一步 x 也只取 1 或 3，所以仅改选行方式不能保证得到最小二乘解。不相容问题交给下一个算法处理。

13.2 扩展 Kaczmarz 算法

上一节的例子说明，方程不相容时，行投影总在各行的解之间来回，原因是右端含有任何 $\boldsymbol{x}$ 都拟合不了的部分。**扩展 Kaczmarz 算法**（extended Kaczmarz method）先用列投影逐步取出这一部分，再对校正后的相容方程作行投影，从而把 Kaczmarz 算法推广到一般的最小二乘问题。

13.2.1 主要思想

由正交分解，$\boldsymbol{b}=\boldsymbol{b}_{\parallel}+\boldsymbol{b}_{\perp}$，其中 $\boldsymbol{b}_{\parallel}\in\operatorname{range}(\boldsymbol{A})$，$\boldsymbol{b}_{\perp}\in\ker(\boldsymbol{A}^{\top})$，$\boldsymbol{b}_{\perp}$ 是不可拟合的部分。由第 9.2节，最小二乘解就是相容方程 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}_{\parallel}$ 的解，其中的最小范数解是 $\boldsymbol{A}^{\dagger}\boldsymbol{b}$。$\boldsymbol{b}_{\perp}$ 事先未知，所以引入一个 m 维辅助向量 $\boldsymbol{z}$ 去逼近它，再求解 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}-\boldsymbol{z}$。

$\boldsymbol{b}_{\perp}$ 由 $\boldsymbol{A}^{\top}\boldsymbol{z}=\boldsymbol{0}$ 刻画，即 $\boldsymbol{z}$ 与每一列正交。记第 j 列为 $\boldsymbol{c}_j$，要让当前 $\boldsymbol{z}_k$ 满足一条齐次方程 $\boldsymbol{c}_j^{\top}\boldsymbol{z}=0$，把上一节的最短修正原理用于这个超平面，得到列投影

$$\boldsymbol{z}_{k+1}=\boldsymbol{z}_k-\frac{\boldsymbol{c}_j^{\top}\boldsymbol{z}_k}{\|\boldsymbol{c}_j\|_2^2}\,\boldsymbol{c}_j. \tag{13.3}$$

它相当于对相容方程 $\boldsymbol{A}^{\top}\boldsymbol{z}=\boldsymbol{0}$ 作一次 Kaczmarz 投影。从 $\boldsymbol{z}_0=\boldsymbol{b}$ 出发，每次减去的都是列的倍数，$\boldsymbol{z}$ 在 $\ker(\boldsymbol{A}^{\top})$ 中的分量始终是 $\boldsymbol{b}_{\perp}$，变化的只是列空间中的部分 $\boldsymbol{z}_k-\boldsymbol{b}_{\perp}$。

若校正量已知为 $\boldsymbol{z}_k$，当前第 i 条目标方程是 $\boldsymbol{a}_i^{\top}\boldsymbol{x} = b_i - (\boldsymbol{z}_k)_i$。沿用式 (13.1)的推导，得到行投影

$$\boldsymbol{x}_{k+1} = \boldsymbol{x}_k + \frac{b_i - (\boldsymbol{z}_k)_i - \boldsymbol{a}_i^{\top}\boldsymbol{x}_k}{\|\boldsymbol{a}_i\|_2^2}\,\boldsymbol{a}_i. \tag{13.4}$$

本章采用同步读取轮初状态的版本：$\boldsymbol{z}_{k+1}$ 和 $\boldsymbol{x}_{k+1}$ 都由 $(\boldsymbol{z}_k, \boldsymbol{x}_k)$ 计算，行更新不改用刚得到的 $\boldsymbol{z}_{k+1}$。先更新 $\boldsymbol{z}$、再用新 $\boldsymbol{z}$ 更新 $\boldsymbol{x}$ 的版本也可以使用，但两种时间顺序产生不同的数值轨迹，实现应与所用的收敛分析一致。这里采用 Zouzias 与 Freris 的随机版本[2]。

[2] A. Zouzias, N. M. Freris, *Randomized Extended Kaczmarz for Solving Least Squares* In SIAM Journal on Matrix Analysis and Applications, 2013, vol. 34, no. 2, pp. 773–793

误差有两个来源。列投影缩小 $\boldsymbol{z}_k - \boldsymbol{b}_{\perp}$；行投影则是在右端仍受这一误差扰动时逼近 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}_{\|}$。$\boldsymbol{x}_0 = \boldsymbol{0}$ 且每步都沿行方向修正，保证 $\boldsymbol{x}_k$ 始终在行空间中，最终选出最小范数代表。

13.2.2 算法实现

初始化与抽样　输入为 $\boldsymbol{A}, \boldsymbol{b}$，输出为 $\boldsymbol{x}$；超参数为绝对容差 atol、相对容差 rtol 和更新次数上限 K。初始化内部状态 $\boldsymbol{x}_0 = \boldsymbol{0}$，$\boldsymbol{z}_0 = \boldsymbol{b}$，并计算各行、各列的平方范数作为抽样权重；若 $\boldsymbol{A} = \boldsymbol{0}$，直接返回最小范数解 $\boldsymbol{x} = \boldsymbol{0}$。每轮独立抽取行 i_k 和列 j_k，概率分别为

$$p_i = \frac{\|\boldsymbol{a}_i\|_2^2}{\|\boldsymbol{A}\|_F^2}, \qquad q_j = \frac{\|\boldsymbol{c}_j\|_2^2}{\|\boldsymbol{A}\|_F^2}.$$

零行和零列的概率为零，不会被抽到，也就不会出现除以零。随机版本同样应记录抽到的行列序列。

列投影　每轮先保存轮初状态 $(\boldsymbol{x}_k, \boldsymbol{z}_k)$，再计算 $\eta_k = \boldsymbol{c}_{j_k}^{\top}\boldsymbol{z}_k / \|\boldsymbol{c}_{j_k}\|_2^2$ 和 $\boldsymbol{z}_{k+1} = \boldsymbol{z}_k - \eta_k \boldsymbol{c}_{j_k}$，即式 (13.3)。旧的 $\boldsymbol{z}_k$ 保留给本轮的行更新使用。

行投影　行投影仍读取旧的 $(\boldsymbol{z}_k)_{i_k}$，计算

$$\gamma_k = \frac{b_{i_k} - (\boldsymbol{z}_k)_{i_k} - \boldsymbol{a}_{i_k}^{\top}\boldsymbol{x}_k}{\|\boldsymbol{a}_{i_k}\|_2^2}, \qquad \boldsymbol{x}_{k+1} = \boldsymbol{x}_k + \gamma_k \boldsymbol{a}_{i_k},$$

完成本轮后才以 $(\boldsymbol{x}_{k+1}, \boldsymbol{z}_{k+1})$ 同时替换旧状态。

停止检查　在初始时和每隔预先规定的轮数，若

$$\|\boldsymbol{b} - \boldsymbol{z}_k - \boldsymbol{A}\boldsymbol{x}_k\|_2 \le \tau_r \quad \text{且} \quad \|\boldsymbol{A}^{\top}\boldsymbol{z}_k\|_2 \le \tau_n,$$

或者已达到 $k = K$，就终止并取 $\boldsymbol{x} = \boldsymbol{x}_k$。阈值按各自的尺度取为 $\tau_r = \mathrm{atol} + \mathrm{rtol}\|\boldsymbol{b}\|_2$ 与 $\tau_n = \mathrm{atol} + \mathrm{rtol}\|\boldsymbol{A}\|_F\|\boldsymbol{b}\|_2$，后者的尺度来自 $\|\boldsymbol{A}^{\top}\boldsymbol{z}_0\|_2 = \|\boldsymbol{A}^{\top}\boldsymbol{b}\|_2 \le \|\boldsymbol{A}\|_F\|\boldsymbol{b}\|_2$。前一项检查 $\boldsymbol{x}_k$ 对校正方程的拟合，后一项检查辅助向量与列空间的正交性；它们只是内部停止判据，$\boldsymbol{z}_k$ 和检查值都不作为输出。停止前再直接计算正规残差 $\boldsymbol{A}^{\top}(\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_k)$ 复核，不要求原残差 $\|\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_k\|_2$ 趋于零。

算例　下面用上一节的不相容例算完两轮，看同步版本怎样使用轮初的校正量。

示例 13.4　扩展 Kaczmarz 算法的前两轮　取 $\boldsymbol{A} = (1,1)^{\top}$，$\boldsymbol{b} = (1,3)^{\top}$：唯一的列 $\boldsymbol{c}_1 = (1,1)^{\top}$ 的平方范数为 2，两行的平方范数都为 1。由正交分解，$\boldsymbol{b}_{\parallel} = 2(1,1)^{\top}$，$\boldsymbol{b}_{\perp} = (-1,1)^{\top}$。初始 $x_0 = 0$，$\boldsymbol{z}_0 = \boldsymbol{b} = (1,3)^{\top}$。

第一轮列投影给出 $\eta_0 = (1+3)/2 = 2$，$\boldsymbol{z}_1 = (1,3)^{\top} - 2(1,1)^{\top} = (-1,1)^{\top}$，已经等于 $\boldsymbol{b}_{\perp}$。行投影用的是旧的 $\boldsymbol{z}_0 = \boldsymbol{b}$，无论抽到哪一行，修正量都是 $b_i - (\boldsymbol{z}_0)_i - x_0 = 0$，所以 $x_1 = 0$ 不动。若行更新改用新的 $\boldsymbol{z}_1$，这一步就会提前得到 $x = 2$；同步版本不这样做。

第二轮列内积为 $-1 + 1 = 0$，所以 $\boldsymbol{z}_2 = \boldsymbol{z}_1 = (-1,1)^{\top}$。若抽到第一行，$\gamma_1 = 1 - (-1) - 0 = 2$；若抽到第二行，$\gamma_1 = 3 - 1 - 0 = 2$。两种情况都得到 $x_2 = 2$，此后不再改变。

最后核验：$\boldsymbol{A}x_2 = (2,2)^{\top} = \boldsymbol{b} - \boldsymbol{z}_2$，$\boldsymbol{A}^{\top}\boldsymbol{z}_2 = 0$，两项停止检查值都为零。原残差 $\boldsymbol{b} - \boldsymbol{A}x_2 = (-1,1)^{\top}$ 不为零，残差平方和为 2，正是 $\min_x[(x-1)^2 + (x-3)^2]$ 的最优值；原方程依然没有精确解，但 $x_2 = 2$ 已经是最小二乘解。

13.2.3 算法分析

极限的含义　列投影只减去列的倍数，保留 $\boldsymbol{b}$ 的正交残差分量 $\boldsymbol{b}_{\perp}$，同时缩小 $\boldsymbol{z}_k - \boldsymbol{b}_{\perp}$；零初值和沿行方向的修正又使 $\boldsymbol{x}_k$ 始终留在行空间中。当 $\boldsymbol{z}_k$ 趋于 $\boldsymbol{b}_{\perp}$ 时，行投影求解的就是相容方程 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}_{\parallel}$，而它在行空间中的唯一解是 $\boldsymbol{A}^{\dagger}\boldsymbol{b}$，所以这一构造指向最小范数最小二乘解。

列校正的收敛　列投影是对相容方程 $\boldsymbol{A}^{\top}\boldsymbol{z} = \boldsymbol{0}$ 作 Kaczmarz 投影，初值为 $\boldsymbol{b}$。由定理 13.3（对 $\boldsymbol{A}^{\top}$ 应用），按固定循环顺序选列时，$\boldsymbol{z}_k$ 收敛到 $\boldsymbol{b}$ 在 $\ker(\boldsymbol{A}^{\top})$ 上的正交投影，即 $\boldsymbol{b}_{\perp}$，每轮按小于一的因子几何收缩。随机选列时，上一节的一步平均估计同样适用于 $\boldsymbol{z}_k - \boldsymbol{b}_{\perp}$，它属于 $\mathrm{range}(\boldsymbol{A})$，平均缩小因子为 $1 - \sigma_r^2/\|\boldsymbol{A}\|_F^2$。

行迭代的误差递推　令 $\boldsymbol{x}_\star = \boldsymbol{A}^\dagger \boldsymbol{b}$，它满足 $\boldsymbol{A}\boldsymbol{x}_\star = \boldsymbol{b}_\parallel = \boldsymbol{b} - \boldsymbol{b}_\perp$，故 $b_i = \boldsymbol{a}_i^\top \boldsymbol{x}_\star + (\boldsymbol{b}_\perp)_i$。代入行投影，误差 $\boldsymbol{\varepsilon}_k = \boldsymbol{x}_k - \boldsymbol{x}_\star$ 满足

$$\boldsymbol{\varepsilon}_{k+1} = \boldsymbol{P}_{i_k} \boldsymbol{\varepsilon}_k + \frac{(\boldsymbol{b}_\perp - \boldsymbol{z}_k)_{i_k}}{\|\boldsymbol{a}_{i_k}\|_2^2} \boldsymbol{a}_{i_k}.$$

第一项是标准 Kaczmarz 的误差映射，第二项是校正误差带来的扰动，长度不超过 $\|\boldsymbol{z}_k - \boldsymbol{b}_\perp\|_2 / \|\boldsymbol{a}_{i_k}\|_2$。$\boldsymbol{\varepsilon}_k$ 始终在行空间中。

在循环版本中，把一轮行扫掠合起来，有 $\|\boldsymbol{\varepsilon}_{\text{轮末}}\|_2 \le q \|\boldsymbol{\varepsilon}_{\text{轮初}}\|_2 + \varphi$，其中 $q < 1$ 是定理 13.3中的因子，φ 是本轮各步扰动长度之和，随 $\boldsymbol{z}_k \to \boldsymbol{b}_\perp$ 趋于零。由这一递推，轮末误差有界；记其上极限为 L，则 $L \le qL$，故 $L = 0$，即 $\boldsymbol{x}_k \to \boldsymbol{A}^\dagger \boldsymbol{b}$。随机版本在规定的独立抽样下，期望平方误差以由 $1 - \sigma_r^2 / \|\boldsymbol{A}\|_F^2$ 决定的几何速率趋于零[3]。，证明同样要用条件期望。这里不宣称每条轨迹的原残差逐步下降，例 13.4中第一轮 x 就完全没有移动。

[3] A. Zouzias, N. M. Freris, *Randomized Extended Kaczmarz for Solving Least Squares* In SIAM Journal on Matrix Analysis and Applications, 2013, vol. 34, no. 2, pp. 773–793

代价　每轮访问一行、一列，并保存长度为 m 的 $\boldsymbol{z}_k$，代价按访问的非零元个数计算；停止检查需要计算 $\boldsymbol{A}\boldsymbol{x}_k$ 与 $\boldsymbol{A}^\top \boldsymbol{z}_k$，各相当于一次完整的矩阵乘向量，所以只按规定间隔进行。数值敏感性仍受原问题小奇异值的影响：两种收缩因子都由 $\sigma_r^2 / \|\boldsymbol{A}\|_F^2$ 决定，它很小时收敛很慢。

13.3　结果检验与停止准则

两种算法的目标不同，检验条件也不同。标准 Kaczmarz 求解相容方程，用原残差 $\|\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_k\|_2$ 检验，并且要用全部方程计算，不能用所选行的残差代替。扩展算法求解一般最小二乘，原残差趋于非零的 $\boldsymbol{b}_\perp$，不能以它为零作为成功标准。

扩展算法的两项内部判据控制了正规残差。令 $\boldsymbol{r}_k = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_k$，由 $\boldsymbol{r}_k = \boldsymbol{z}_k + (\boldsymbol{b} - \boldsymbol{z}_k - \boldsymbol{A}\boldsymbol{x}_k)$ 得

$$\|\boldsymbol{A}^\top \boldsymbol{r}_k\|_2 \le \|\boldsymbol{A}^\top \boldsymbol{z}_k\|_2 + \|\boldsymbol{A}\|_2 \, \|\boldsymbol{b} - \boldsymbol{z}_k - \boldsymbol{A}\boldsymbol{x}_k\|_2,$$

所以两项都小时，最小二乘的正交条件 $\boldsymbol{A}^\top \boldsymbol{r} = \boldsymbol{0}$ 的偏离也小；停止前再直接计算 $\boldsymbol{A}^\top(\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_k)$ 复核。最小范数的要求则不由这些残差检验，而是由零初值和迭代始终留在行空间中保证。

两种方法的输出都只是当前的 $\boldsymbol{x}$，达到次数上限不代表已经达到目标精度。比较速度时要区分一次行投影、一次完整扫掠和 Krylov 方法中含矩阵乘法的一次迭代：一次行投影只读一行，一轮扫掠才相当于一次矩阵乘向量，再把抽样权重的准备和全局残差检查计入总成本。结果的误差解释和方法选择分别见第 14.1节和第 14.3节。

13.4 本章小结

本章回答了只能逐行或逐列访问数据时怎样求解线性方程。Kaczmarz 算法每次只满足一个方程：由最短修正原理，更新沿所选行的法向进行，步长由行残差除以行的平方范数确定，新点是当前点到该超平面的正交投影。方程相容时，每一步到每个精确解的距离都不增；循环版本每轮按小于一的因子收缩，收敛到 $\boldsymbol{A}^{\dagger}\boldsymbol{b}$ 加上初值的零空间分量，零初值时就是最小范数解。随机版本按行的平方范数抽样，期望平方误差以 $1-\sigma_r^2/\|\boldsymbol{A}\|_F^2$ 为因子几何减小。

使用时要注意几个条件。行之间越接近平行，收敛越慢；零行对应非零右端说明方程不相容，必须单独处理；某一行的残差为零不说明求解完成。方程不相容时，标准 Kaczmarz 在各行的解之间往返，不论循环还是随机选行都不会停在最小二乘解上。

扩展 Kaczmarz 算法把右端分成可拟合与不可拟合两部分：列投影从 $\boldsymbol{z}_0=\boldsymbol{b}$ 出发逼近不可拟合的 $\boldsymbol{b}_{\perp}$，行投影求解校正后的相容方程 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}-\boldsymbol{z}$。本章采用同步版本，两种投影都读取轮初状态；零初值保证极限是最小范数最小二乘解。

检验时，标准算法看全部方程的原残差；扩展算法看 $\|\boldsymbol{A}^{\top}\boldsymbol{z}\|_2$ 与校正方程的残差，并复核正规残差，原残差最终非零是正常的。两种算法的最小范数性质都依赖零初值和行空间保持，不由残差判据保证。它们每步只读一行或一列，代价低，但收敛速度受 $\sigma_r^2/\|\boldsymbol{A}\|_F^2$ 限制；误差解释与方法比较在第 14章进行。

第 14 章

求解误差、正则化与方法选择

前几章给出了多条求解路线：直接分解、定常迭代、Krylov 子空间法与行列投影法。每条路线最后都交出一个向量，但交出来的向量并不都同样可信。设两列几乎平行的矩阵配上略有误差的观测：精确地解出方程，系数可能离真实值很远；换成另一种算法，可能连这个精确解也没有算准；迭代法提前停下，又多出一份截断误差。即使残差已经很小，也不能直接断言系数可靠。

本章回答三个问题：算出的解能相信多少，问题本身太敏感时怎么办，以及在多种方法都可用时怎样选择。

第 14.1节先把误差的来源分开。数据误差经问题本身放大，用有限扰动界与条件数度量；近似解的质量用残差、前向误差与后向误差判断；最小二乘的系数、拟合值与残差敏感程度不同；矩阵的秩一旦变化，伪逆可能不连续，数值秩要结合误差水平确定。这里用到第 7章的条件数与奇异值扰动界，以及第 9章的伪逆与选解。

第 14.2节处理敏感性本身无法由算法消除的情形。岭回归与 Tikhonov 正则化在目标中加入惩罚，谱截断正则化舍弃小奇异值方向，二者都主动改变求解目标，用拟合误差与偏差换取稳定。截断所用矩阵的最佳低秩性质留到第 15章。

第 14.3节在前两节建立的误差标准下，把第 10—13章的方法放回同一组问题中比较：先确定求解目标，再看矩阵条件、计算开销与收敛速度、数值稳定性，最后给出典型问题的取舍。本章的误差分析都针对有限大小的扰动；扰动趋于零时的局部线性化观点在第 20章讨论。

14.1 解的误差与敏感性

求解目标确定、算法也给出结果以后，还要回答算出的结果能相信多少。本节分四方面讨论：数据的扰动怎样传到解，算出的近似解怎样用残差判断，最小二乘的不同输出各有多敏感，以及矩阵的秩变化时伪逆怎样变化。

讨论每种误差都先说清以什么为参照、允许修改哪些数据。比较两个精确解时，修改的是 $\boldsymbol{A}$ 或 $\boldsymbol{b}$；用残差判断近似解时，数据不改，参照的是未知的真解；后向误差则反过来问，数据至少要改多少，近似解才成为精确解。

以下结论都由精确方程、范数估计和奇异值性质建立，扰动可以有有限大小；所用的条件数与奇异值扰动界来自第 7章。第 18章建立逆矩阵等运算的微分公式，第 20章再从同样的精确关系中提取解映射的一阶响应，讨论局部条件数与一阶近似的余项，那是扰动趋于零时的局部观点。

14.1.1 系数矩阵与右端项的扰动

本小节设 $\boldsymbol{A}\in\mathbb{R}^{d\times d}$ 可逆，$\boldsymbol{b}\neq\boldsymbol{0}$，精确解 $\boldsymbol{x}_\star=\boldsymbol{A}^{-1}\boldsymbol{b}$。向量范数与它诱导的矩阵范数始终取同一种，记 $\kappa(\boldsymbol{A})=\|\boldsymbol{A}\|\|\boldsymbol{A}^{-1}\|$。

右端扰动　先固定 $\boldsymbol{A}$，只把右端改为 $\boldsymbol{b}+\Delta\boldsymbol{b}$。两个方程相减，解的变化 $\Delta\boldsymbol{x}=\boldsymbol{A}^{-1}\Delta\boldsymbol{b}$ 对任意大小的 $\Delta\boldsymbol{b}$ 都精确成立。取范数得 $\|\Delta\boldsymbol{x}\|\le\|\boldsymbol{A}^{-1}\|\|\Delta\boldsymbol{b}\|$，再用 $\|\boldsymbol{b}\|\le\|\boldsymbol{A}\|\|\boldsymbol{x}_\star\|$ 得到相对误差界

$$\frac{\|\Delta\boldsymbol{x}\|}{\|\boldsymbol{x}_\star\|}\le\kappa(\boldsymbol{A})\,\frac{\|\Delta\boldsymbol{b}\|}{\|\boldsymbol{b}\|},$$

这就是第 7.1.3节的条件数界（定理 7.7）。

哪些右端误差放大得最多，可以由奇异值分解 $\boldsymbol{A}=\sum_i\sigma_i\boldsymbol{u}_i\boldsymbol{v}_i^{\top}$ 读出。把 $\Delta\boldsymbol{b}$ 展开为 $\sum_i\beta_i\boldsymbol{u}_i$，就有 $\Delta\boldsymbol{x}=\sum_i(\beta_i/\sigma_i)\boldsymbol{v}_i$：沿 $\boldsymbol{u}_i$ 的误差被放大 $1/\sigma_i$ 倍，落在最小奇异值方向上时放大最多。下面的例子都在精确算术中计算，放大完全来自问题本身，与算法和舍入无关。

示例 14.1　良态矩阵与近平行列矩阵　先看一个良态的对照。取 $\boldsymbol{A}_1=\operatorname{diag}(2,1)$，$\kappa_2(\boldsymbol{A}_1)=2$。右端由 $(2,1)^{\top}$ 改为 $(2,1.01)^{\top}$，解由 $(1,1)^{\top}$ 变为 $(1,1.01)^{\top}$，右端与解的相对变化分别约为 0.0045 与 0.0071，放大约 1.6 倍。

再取两列接近同向的矩阵

$$\boldsymbol{A}_2=\begin{bmatrix}1 & 1\\ 0 & \varepsilon\end{bmatrix},\qquad \varepsilon=10^{-2}.$$

$\boldsymbol{A}_2^{\top}\boldsymbol{A}_2$ 的迹为 $2+\varepsilon^2$、行列式为 ε^2，所以 $\sigma_{\max}\approx\sqrt{2}$，$\sigma_{\min}\approx\varepsilon/\sqrt{2}$，$\kappa_2(\boldsymbol{A}_2)\approx 2/\varepsilon = 200$。右端由 $(2,0)^{\top}$ 改为 $(2,0.01)^{\top}$，解由 $(2,0)^{\top}$ 变为 $(1,1)^{\top}$：右端的相对变化为 0.005，解的相对变化约为 0.707，放大约 141 倍。

同样大小的右端扰动，在第二个矩阵上造成的解的相对变化大了约百倍。解的变化 $(-1,1)^{\top}$ 几乎正沿着小奇异值对应的右奇异方向，两个系数此增彼减。图 14.1画出了 ε 减小时这种分裂怎样加剧。

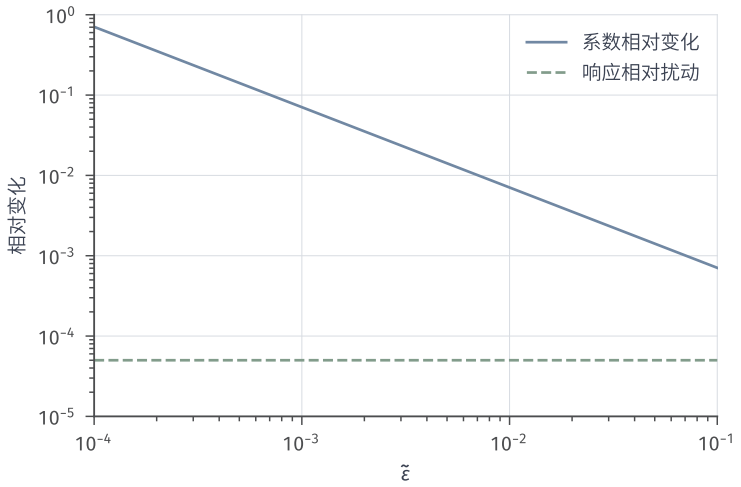


图 14.1　近平行列的系数分裂：对 $\boldsymbol{A}_2=\left[\begin{smallmatrix}1&1\\0&\varepsilon\end{smallmatrix}\right]$ 固定右端扰动 η，ε 越小，两个系数沿相反方向偏离 $(2,0)$ 越远，绝对误差随 $1/\varepsilon$ 增长。

系数矩阵的扰动　系数矩阵也带误差时，扰动后的矩阵 $\boldsymbol{B}=\boldsymbol{A}+\boldsymbol{E}$ 甚至可能不可逆。所以要先确定它何时可逆，再估计 $\boldsymbol{B}^{-1}$ 离 $\boldsymbol{A}^{-1}$ 多远。

定理 14.2　逆矩阵的有限扰动　设 $\boldsymbol{A}\in\mathbb{R}^{d\times d}$ 可逆，$\boldsymbol{B}=\boldsymbol{A}+\boldsymbol{E}$。

1. 若 $\|\boldsymbol{A}^{-1}\boldsymbol{E}\|<1$，则 $\boldsymbol{B}$ 可逆，$\|\boldsymbol{B}^{-1}\|\le\|\boldsymbol{A}^{-1}\|/(1-\|\boldsymbol{A}^{-1}\boldsymbol{E}\|)$，且

$$\boldsymbol{B}^{-1}-\boldsymbol{A}^{-1}=-\boldsymbol{B}^{-1}\boldsymbol{E}\,\boldsymbol{A}^{-1}. \tag{14.1}$$

2. 若 $q=\|\boldsymbol{A}^{-1}\|\|\boldsymbol{E}\|<1$，则第 1 条适用，并且

$$\frac{\|\boldsymbol{B}^{-1}-\boldsymbol{A}^{-1}\|}{\|\boldsymbol{A}^{-1}\|}\le\frac{q}{1-q},\qquad q=\kappa(\boldsymbol{A})\frac{\|\boldsymbol{E}\|}{\|\boldsymbol{A}\|}.$$

证明 若 $\boldsymbol{B}\boldsymbol{x}=\boldsymbol{0}$，则 $\boldsymbol{x}=-\boldsymbol{A}^{-1}\boldsymbol{E}\boldsymbol{x}$，取范数得 $\|\boldsymbol{x}\|\le\|\boldsymbol{A}^{-1}\boldsymbol{E}\|\|\boldsymbol{x}\|$，只能 $\boldsymbol{x}=\boldsymbol{0}$，故方阵 $\boldsymbol{B}$ 可逆。对任意 $\boldsymbol{y}$ 令 $\boldsymbol{x}=\boldsymbol{B}^{-1}\boldsymbol{y}$，由 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{y}-\boldsymbol{E}\boldsymbol{x}$ 得 $\boldsymbol{x}=\boldsymbol{A}^{-1}\boldsymbol{y}-\boldsymbol{A}^{-1}\boldsymbol{E}\boldsymbol{x}$，取范数并移项得 $(1-\|\boldsymbol{A}^{-1}\boldsymbol{E}\|)\|\boldsymbol{x}\|\le\|\boldsymbol{A}^{-1}\|\|\boldsymbol{y}\|$，即 $\|\boldsymbol{B}^{-1}\|$ 的界。恒等式由 $\boldsymbol{B}^{-1}(\boldsymbol{A}-\boldsymbol{B})\boldsymbol{A}^{-1}=\boldsymbol{B}^{-1}-\boldsymbol{A}^{-1}$ 得到。第 2 条中 $\|\boldsymbol{A}^{-1}\boldsymbol{E}\|\le q<1$；对式 (14.1)取范数，得 $\|\boldsymbol{B}^{-1}-\boldsymbol{A}^{-1}\|\le\|\boldsymbol{A}^{-1}\|^{2}\|\boldsymbol{E}\|/(1-q)$，再除以 $\|\boldsymbol{A}^{-1}\|$。 ■

界的分子是条件数乘相对扰动，分母 $1-q$ 是到奇异边界的余量。对角矩阵说明这个界可以取到：取 $\boldsymbol{A}=\operatorname{diag}(1,\varepsilon)$ 与 $\boldsymbol{E}=\operatorname{diag}(0,-\delta)$，$0<\delta<\varepsilon<1$，在谱范数下 $q=\delta/\varepsilon$，逆矩阵的相对变化恰为 $\delta/(\varepsilon-\delta)=q/(1-q)$，$\delta\to\varepsilon$ 时无界。反过来，$q\ge1$ 只表示定理不再给出保证，并不意味着 $\boldsymbol{B}$ 已经奇异，例如 $\boldsymbol{E}=\boldsymbol{A}$ 时 $\boldsymbol{B}=2\boldsymbol{A}$ 仍可逆。

矩阵与右端同时扰动 矩阵与右端同时扰动时，扰动后的方程为 $(\boldsymbol{A}+\boldsymbol{E})(\boldsymbol{x}_\star+\Delta\boldsymbol{x})=\boldsymbol{b}+\Delta\boldsymbol{b}$，减去原方程得到精确关系

$$(\boldsymbol{A}+\boldsymbol{E})\Delta\boldsymbol{x}=\Delta\boldsymbol{b}-\boldsymbol{E}\boldsymbol{x}_\star. \tag{14.2}$$

解的变化由两部分驱动：右端的变化，以及矩阵变化作用在原解上产生的 $\boldsymbol{E}\boldsymbol{x}_\star$。在定理 14.2的条件下，它可以写成 $\Delta\boldsymbol{x}=(\boldsymbol{A}+\boldsymbol{E})^{-1}(\Delta\boldsymbol{b}-\boldsymbol{E}\boldsymbol{x}_\star)$。

定理 14.3 矩阵与右端同时扰动时的解误差 设 $\rho_A=\|\boldsymbol{E}\|/\|\boldsymbol{A}\|$，$\rho_b=\|\Delta\boldsymbol{b}\|/\|\boldsymbol{b}\|$。若 $\kappa(\boldsymbol{A})\rho_A<1$，则 $\boldsymbol{A}+\boldsymbol{E}$ 可逆，且

$$\frac{\|\Delta\boldsymbol{x}\|}{\|\boldsymbol{x}_\star\|}\le\frac{\kappa(\boldsymbol{A})\,(\rho_A+\rho_b)}{1-\kappa(\boldsymbol{A})\rho_A}. \tag{14.3}$$

证明 可逆性由定理 14.2第 2 条得到。把式 (14.2)改写为 $\Delta\boldsymbol{x}=\boldsymbol{A}^{-1}(\Delta\boldsymbol{b}-\boldsymbol{E}\boldsymbol{x}_\star-\boldsymbol{E}\Delta\boldsymbol{x})$，取范数得

$$\|\Delta\boldsymbol{x}\|\le\|\boldsymbol{A}^{-1}\|\big(\|\Delta\boldsymbol{b}\|+\|\boldsymbol{E}\|\|\boldsymbol{x}_\star\|+\|\boldsymbol{E}\|\|\Delta\boldsymbol{x}\|\big).$$

把含 $\|\Delta\boldsymbol{x}\|$ 的项移到左边，两边除以 $\|\boldsymbol{x}_\star\|$，再用 $\|\Delta\boldsymbol{b}\|\le\rho_b\|\boldsymbol{A}\|\|\boldsymbol{x}_\star\|$ 即得。 ■

两类相对扰动先相加，再被条件数放大，最后除以到奇异边界的余量；$\boldsymbol{E}=\boldsymbol{0}$ 时退回只扰动右端的界。第 20.2.2节从同一精确式 (14.2)提取解映射的一阶响应，这里保留的是对完整变化有效的结论。

14.1.2 残差、前向误差与后向误差

残差与前向误差 上一小节比较两个精确解。实际计算只给出一个近似解 $\tilde{\boldsymbol{x}}$，真解未知，能直接算出的是残差 $\boldsymbol{r} = \boldsymbol{b} - \boldsymbol{A}\tilde{\boldsymbol{x}}$。由 $\boldsymbol{A}(\boldsymbol{x}_\star - \tilde{\boldsymbol{x}}) = \boldsymbol{r}$，误差是 $\boldsymbol{x}_\star - \tilde{\boldsymbol{x}} = \boldsymbol{A}^{-1}\boldsymbol{r}$，残差扮演了右端误差的角色，于是

$$\frac{\|\tilde{\boldsymbol{x}} - \boldsymbol{x}_\star\|}{\|\boldsymbol{x}_\star\|} \le \kappa(\boldsymbol{A}) \frac{\|\boldsymbol{r}\|}{\|\boldsymbol{b}\|}.$$

病态时小残差什么也不保证。取 $\boldsymbol{A} = \operatorname{diag}(1, \varepsilon)$、$\boldsymbol{b} = (1, \varepsilon)^{\mathsf{T}}$，真解为 $(1,1)^{\mathsf{T}}$；近似解 $\tilde{\boldsymbol{x}} = (1,0)^{\mathsf{T}}$ 的残差 $(0,\varepsilon)^{\mathsf{T}}$ 随 $\varepsilon \to 0$ 趋于零，相对误差却始终是 $1/\sqrt{2}$。

因此要区分两种误差。近似解离真解多远，即 $\|\tilde{\boldsymbol{x}} - \boldsymbol{x}_\star\|$ 或其相对量，称为**前向误差**（forward error）。至少要把数据修改多少，才能让 $\tilde{\boldsymbol{x}}$ 成为修改后问题的精确解，称为**后向误差**（backward error）。前者需要真解才能算，后者只用数据和近似解就能算，下面先说明它的度量方式。

后向误差的度量 后向误差的大小取决于允许怎样修改数据。范数型模型只限制 $\|\Delta\boldsymbol{A}\| \le \epsilon\|\boldsymbol{A}\|$ 与 $\|\Delta\boldsymbol{b}\| \le \epsilon\|\boldsymbol{b}\|$，满足 $(\boldsymbol{A} + \Delta\boldsymbol{A})\tilde{\boldsymbol{x}} = \boldsymbol{b} + \Delta\boldsymbol{b}$ 的最小 ϵ 记作 $\eta(\tilde{\boldsymbol{x}})$。在二范数下它可以由残差直接算出。

定理 14.4 范数型后向误差 设 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$，$\tilde{\boldsymbol{x}} \in \mathbb{R}^{d}$，$\boldsymbol{r} = \boldsymbol{b} - \boldsymbol{A}\tilde{\boldsymbol{x}}$，且 $s = \|\boldsymbol{A}\|_2\|\tilde{\boldsymbol{x}}\|_2 + \|\boldsymbol{b}\|_2 > 0$。则在二范数下

$$\eta_2(\tilde{\boldsymbol{x}}) = \frac{\|\boldsymbol{r}\|_2}{\|\boldsymbol{A}\|_2\|\tilde{\boldsymbol{x}}\|_2 + \|\boldsymbol{b}\|_2},$$

并且下确界可以取到。

证明 若 $(\boldsymbol{A} + \Delta\boldsymbol{A})\tilde{\boldsymbol{x}} = \boldsymbol{b} + \Delta\boldsymbol{b}$ 且两项相对大小不超过 ϵ，则 $\boldsymbol{r} = \Delta\boldsymbol{A}\tilde{\boldsymbol{x}} - \Delta\boldsymbol{b}$，$\|\boldsymbol{r}\|_2 \le \epsilon s$，所以 $\epsilon \ge \|\boldsymbol{r}\|_2/s$。反过来，$\tilde{\boldsymbol{x}} = \boldsymbol{0}$ 时取 $\Delta\boldsymbol{A} = \boldsymbol{0}$、$\Delta\boldsymbol{b} = -\boldsymbol{b}$；$\tilde{\boldsymbol{x}} \neq \boldsymbol{0}$ 时取

$$\Delta\boldsymbol{A} = \frac{\|\boldsymbol{A}\|_2}{s\|\tilde{\boldsymbol{x}}\|_2}\,\boldsymbol{r}\tilde{\boldsymbol{x}}^{\mathsf{T}}, \qquad \Delta\boldsymbol{b} = -\frac{\|\boldsymbol{b}\|_2}{s}\,\boldsymbol{r}.$$

秩一矩阵 $\boldsymbol{r}\tilde{\boldsymbol{x}}^{\mathsf{T}}$ 的谱范数为 $\|\boldsymbol{r}\|_2\|\tilde{\boldsymbol{x}}\|_2$，两项的相对大小都等于 $\|\boldsymbol{r}\|_2/s$，且 $\Delta\boldsymbol{A}\tilde{\boldsymbol{x}} - \Delta\boldsymbol{b} = \boldsymbol{r}$，即 $(\boldsymbol{A} + \Delta\boldsymbol{A})\tilde{\boldsymbol{x}} = \boldsymbol{b} + \Delta\boldsymbol{b}$。 ■

分母为零只发生在 $\boldsymbol{b} = \boldsymbol{0}$ 且 $\tilde{\boldsymbol{x}} = \boldsymbol{0}$ 时，这时 $\tilde{\boldsymbol{x}}$ 已是精确解。这个公式说明，迭代法常用的归一化残差恰好就是范数型后向误差（第 11.7节、第 12.12节）。

逐元素模型改为限制 $|\Delta \boldsymbol{A}| \le \epsilon |\boldsymbol{A}|$ 与 $|\Delta \boldsymbol{b}| \le \epsilon |\boldsymbol{b}|$（绝对值与不等号逐元素取），它不允许把零元改成非零，所得后向误差为 $\max_i |r_i| / (|\boldsymbol{A}||\tilde{\boldsymbol{x}}| + |\boldsymbol{b}|)_i$[1]。上面的对角例子中，范数型后向误差约为 $\varepsilon/2$，逐元素后向误差却是 1：第二个方程按自身尺度完全没有被满足。两种模型回答不同的问题，由一种模型得到的结论不能不加说明地用于另一种。

[1] G. H. Golub, C. F. Van Loan, *Matrix Computations*, Johns Hopkins University Press, 2013, 4th ed.

示例 14.5　计算一次后向误差　取示例 11.1的 $\boldsymbol{A} = \left[\begin{smallmatrix} 4 & 1 \\ 1 & 3 \end{smallmatrix}\right]$ 与 $\boldsymbol{b} = (1, 2)^{\mathsf{T}}$，精确解 $\boldsymbol{x}_\star = (1/11, 7/11)^{\mathsf{T}} \approx (0.0909, 0.6364)^{\mathsf{T}}$。设某个算法给出近似解 $\tilde{\boldsymbol{x}} = (0.09, 0.64)^{\mathsf{T}}$，我们来算它的范数型后向误差。残差为 $\boldsymbol{r} = (1 - 0.36 - 0.64,\ 2 - 0.09 - 1.92)^{\mathsf{T}} = (0, -0.01)^{\mathsf{T}}$。

分母要用到几个范数。$\boldsymbol{A}$ 对称，特征值 $(7 \pm \sqrt{5})/2$，故 $\|\boldsymbol{A}\|_2 \approx 4.618$，$\kappa_2(\boldsymbol{A}) \approx 1.939$；又 $\|\tilde{\boldsymbol{x}}\|_2 \approx 0.6463$，$\|\boldsymbol{b}\|_2 = \sqrt{5} \approx 2.236$，分母 $s \approx 4.618 \times 0.6463 + 2.236 \approx 5.221$，于是 $\eta_2(\tilde{\boldsymbol{x}}) \approx 0.01 / 5.221 \approx 1.92 \times 10^{-3}$。按定理中的构造，

$$\Delta \boldsymbol{A} \approx \begin{bmatrix} 0 & 0 \\ -0.0012 & -0.0088 \end{bmatrix}, \qquad \Delta \boldsymbol{b} \approx \begin{bmatrix} 0 \\ 0.0043 \end{bmatrix},$$

可以直接验证 $(\boldsymbol{A} + \Delta \boldsymbol{A})\tilde{\boldsymbol{x}} = \boldsymbol{b} + \Delta \boldsymbol{b}$。

也就是说，$\tilde{\boldsymbol{x}}$ 是一个只差千分之二左右的邻近问题的精确解。实际的相对前向误差为 $\|\tilde{\boldsymbol{x}} - \boldsymbol{x}_\star\|_2 / \|\boldsymbol{x}_\star\|_2 \approx 0.0058$，不超过下面定理 14.6给出的 $2\kappa_2\eta_2 / (1 - \kappa_2\eta_2) \approx 0.0075$；条件数不到 2，所以小的后向误差在这里确实带来小的前向误差。

后向稳定与常用分解　计算机中每次基本运算满足 $\mathrm{fl}(x \circ y) = (x \circ y)(1 + \delta)$，$|\delta| \le u$，$u$ 称为单位舍入，双精度时 $u \approx 1.1 \times 10^{-16}$。若算法对所有合法输入算出的结果都是某个邻近问题的精确解，且后向误差不超过 u 乘一个只依赖维数的温和常数，就称算法**后向稳定**（backward stable）。后向稳定算法的前向误差仍受条件数制约，这由下面的定理给出。

定理 14.6　由后向误差估计前向误差　设 $\boldsymbol{A} \in \mathbb{R}^{d \times d}$ 可逆，$\boldsymbol{b} \neq \boldsymbol{0}$。若 $(\boldsymbol{A} + \Delta \boldsymbol{A})\tilde{\boldsymbol{x}} = \boldsymbol{b} + \Delta \boldsymbol{b}$，$\|\Delta \boldsymbol{A}\| \le \eta \|\boldsymbol{A}\|$，$\|\Delta \boldsymbol{b}\| \le \eta \|\boldsymbol{b}\|$，且 $\kappa(\boldsymbol{A})\eta < 1$，则

$$\frac{\|\tilde{\boldsymbol{x}} - \boldsymbol{x}_\star\|}{\|\boldsymbol{x}_\star\|} \le \frac{2\kappa(\boldsymbol{A})\,\eta}{1 - \kappa(\boldsymbol{A})\,\eta}.$$

证明　把 $\tilde{\boldsymbol{x}}$ 看作扰动问题的精确解，在定理 14.3中取 $\boldsymbol{E} = \Delta \boldsymbol{A}$，$\rho_A, \rho_b \le \eta$。 ∎

所以前向误差大约不超过条件数乘后向误差：后向误差评价算法或近似解，条件数评价问题。$\kappa(\boldsymbol{A})u$ 接近 1 时，即使算法后向稳定，答案也可能没有一位有效数字。第 10章各直接法的稳定性以此为标准[2]。

[2] G. H. Golub, C. F. Van Loan, *Matrix Computations*, Johns Hopkins University Press, 2013, 4th ed.

带部分主元的 LU（第 10.1节）的后向误差约为 d 的低次幂乘增长因子 ρ 再乘 u，其中 ρ 是消元中出现的最大元素与 $\boldsymbol{A}$ 最大元素之比。部分主元使乘子不超过 1，但 ρ 最坏可达 2^{d-1}，所以它只在增长因子不大时后向稳定，实际中可以在消元时记录 ρ。

Cholesky 分解（第 10.2节）由 $a_{j,j} = \sum_k l_{j,k}^2$ 知因子元素不超过 $\sqrt{a_{j,j}}$，没有增长问题，对正定矩阵后向稳定。Householder 反射与 Givens 旋转（第 10.7节）保持长度，前面步骤的误差不被后续变换放大，用它们求最小二乘解是后向稳定的。修正 Gram–Schmidt 不用正交矩阵作用于数据，算出的 $\boldsymbol{Q}$ 在有限精度下可能偏离正交，应核验 $\boldsymbol{Q}^{\top}\boldsymbol{Q} - \boldsymbol{I}$ 或残差。

14.1.3 最小二乘的敏感性与数值误差

三类输出的敏感性 最小二乘有三类输出：系数 $\hat{\boldsymbol{x}} = \boldsymbol{A}^{\dagger}\boldsymbol{b}$、拟合值 $\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{A}\boldsymbol{A}^{\dagger}\boldsymbol{b}$ 与残差 $\hat{\boldsymbol{r}} = (\boldsymbol{I} - \boldsymbol{A}\boldsymbol{A}^{\dagger})\boldsymbol{b}$，其中 $\boldsymbol{P} = \boldsymbol{A}\boldsymbol{A}^{\dagger}$ 是到 range $\boldsymbol{A}$ 的正交投影（第 9.4节）。固定 $\boldsymbol{A}$，右端改变 $\Delta\boldsymbol{b}$ 时，三者都是 $\boldsymbol{b}$ 的线性函数，变化精确地为

$$\Delta\hat{\boldsymbol{x}} = \boldsymbol{A}^{\dagger}\Delta\boldsymbol{b}, \qquad \Delta(\boldsymbol{A}\hat{\boldsymbol{x}}) = \boldsymbol{P}\Delta\boldsymbol{b}, \qquad \Delta\hat{\boldsymbol{r}} = (\boldsymbol{I} - \boldsymbol{P})\Delta\boldsymbol{b}.$$

三者的敏感程度不同。后两项正交，$\|\boldsymbol{P}\Delta\boldsymbol{b}\|_2^2 + \|(\boldsymbol{I}-\boldsymbol{P})\Delta\boldsymbol{b}\|_2^2 = \|\Delta\boldsymbol{b}\|_2^2$，拟合值与残差的绝对变化都不超过 $\|\Delta\boldsymbol{b}\|_2$。系数却满足 $\|\Delta\hat{\boldsymbol{x}}\|_2 \le \|\Delta\boldsymbol{b}\|_2/\sigma_r$，$\sigma_r$ 为最小正奇异值，$\Delta\boldsymbol{b}$ 沿第 r 个左奇异向量时取等号。所以拟合得好与系数可靠是两回事。

还有两点限制。某个输出接近零时，例如接近相容问题的残差，它的相对变化可能很大而绝对变化仍受控，相对误差的解释要重新检查。这里只改变了右端；$\boldsymbol{A}$ 也变化时，残差会通过 $\boldsymbol{A}$ 的变化进入系数，误差界中出现与 $\kappa_2(\boldsymbol{A})^2\|\hat{\boldsymbol{r}}\|_2$ 成比例的项[3]。，所以 $\kappa_2(\boldsymbol{A})$ 不是同时改变 $\boldsymbol{A}, \boldsymbol{b}$ 时所有输出的完整条件数。

[3] G. H. Golub, C. F. Van Loan, *Matrix Computations*, Johns Hopkins University Press, 2013, 4th ed.

正规方程的条件数平方 第 10.6节对满列秩长方矩阵定义了 $\kappa_2(\boldsymbol{A}) = \sigma_{\max}(\boldsymbol{A})/\sigma_{\min}(\boldsymbol{A})$。正规方程法的风险由下面的关系刻画。

对满列秩的 $\boldsymbol{A}$，$\kappa_2(\boldsymbol{A}) = \|\boldsymbol{A}\|_2\|\boldsymbol{A}^{\dagger}\|_2$：由伪逆的奇异值表示，$\boldsymbol{A}^{\dagger}$ 的最大奇异值为 $1/\sigma_{\min}(\boldsymbol{A})$，这与方阵的 $\|\boldsymbol{A}\|\|\boldsymbol{A}^{-1}\|$ 形式一致。由定理 10.17，

$$\kappa_2(\boldsymbol{A}^{\top}\boldsymbol{A}) = \kappa_2(\boldsymbol{A})^2. \tag{14.4}$$

正规方程法即使以后向稳定的方式形成并求解 $\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{x}=\boldsymbol{A}^{\top}\boldsymbol{b}$，定理 14.6给出的放大因子也是 $\kappa_2(\boldsymbol{A})^2$，与残差大小无关。对示例 14.1的 $\boldsymbol{A}_2$ 取 $\varepsilon=10^{-8}$：$\kappa_2(\boldsymbol{A}_2)\approx 2\times 10^{8}$，远未达到 $1/u$，两列在双精度下仍可区分。但 Gram 矩阵的元素 $1+\varepsilon^2$ 在舍入后就是 1，存下来的 $\boldsymbol{A}_2^{\top}\boldsymbol{A}_2$ 成为奇异矩阵 $\left[\begin{smallmatrix}1&1\\1&1\end{smallmatrix}\right]$，有用的信息在形成这一步就丢失了。

QR 与 SVD 直接作用于 $\boldsymbol{A}$，算出的解是邻近数据的精确最小二乘解，舍入误差的放大因子是 $\kappa_2(\boldsymbol{A})$ 加上以 $\|\hat{\boldsymbol{r}}\|_2$ 为权的 $\kappa_2(\boldsymbol{A})^2$ 项；残差小时它与 $\kappa_2(\boldsymbol{A})$ 同阶，正规方程却总带着平方。两条路线代数上等价，数值表现不同；正规方程法只在 $\kappa_2(\boldsymbol{A})^2 u$ 远小于 1 时可取。

14.1.4 伪逆扰动与数值秩

伪逆的扰动与不连续 一般矩阵改变时，伪逆的变化取决于最小正奇异值是否远离零。设 $\boldsymbol{B}=\boldsymbol{A}+\boldsymbol{E}$，直接展开可以验证

$$\boldsymbol{B}^{\dagger}-\boldsymbol{A}^{\dagger}=-\boldsymbol{B}^{\dagger}\boldsymbol{E}\boldsymbol{A}^{\dagger}+\boldsymbol{B}^{\dagger}(\boldsymbol{I}-\boldsymbol{A}\boldsymbol{A}^{\dagger})-(\boldsymbol{I}-\boldsymbol{B}^{\dagger}\boldsymbol{B})\boldsymbol{A}^{\dagger},$$

因为第一项等于 $-\boldsymbol{B}^{\dagger}\boldsymbol{B}\boldsymbol{A}^{\dagger}+\boldsymbol{B}^{\dagger}\boldsymbol{A}\boldsymbol{A}^{\dagger}$，与后两项的交叉项全部抵消。由此得到下面的估计。

定理 14.7　伪逆的扰动界 若存在 $s_0>0$，使 $\boldsymbol{A}$ 与 $\boldsymbol{B}=\boldsymbol{A}+\boldsymbol{E}$ 的全部正奇异值都不小于 s_0，则

$$\|\boldsymbol{B}^{\dagger}-\boldsymbol{A}^{\dagger}\|_2\le\frac{3\|\boldsymbol{E}\|_2}{s_0^2}. \tag{14.5}$$

证明 由假设，$\|\boldsymbol{A}^{\dagger}\|_2,\|\boldsymbol{B}^{\dagger}\|_2\le 1/s_0$，第一项不超过 $\|\boldsymbol{E}\|_2/s_0^2$。第二项中，由 Penrose 条件 $\boldsymbol{B}^{\dagger}=\boldsymbol{B}^{\dagger}(\boldsymbol{B}\boldsymbol{B}^{\dagger})^{\top}=\boldsymbol{B}^{\dagger}(\boldsymbol{B}^{\dagger})^{\top}\boldsymbol{B}^{\top}$，又 $\boldsymbol{A}^{\top}(\boldsymbol{I}-\boldsymbol{A}\boldsymbol{A}^{\dagger})=\boldsymbol{0}$，所以 $\boldsymbol{B}^{\top}(\boldsymbol{I}-\boldsymbol{A}\boldsymbol{A}^{\dagger})=\boldsymbol{E}^{\top}(\boldsymbol{I}-\boldsymbol{A}\boldsymbol{A}^{\dagger})$，该项等于 $\boldsymbol{B}^{\dagger}(\boldsymbol{B}^{\dagger})^{\top}\boldsymbol{E}^{\top}(\boldsymbol{I}-\boldsymbol{A}\boldsymbol{A}^{\dagger})$；正交投影的范数不超过 1，它不超过 $\|\boldsymbol{E}\|_2/s_0^2$。第三项同理写 $\boldsymbol{A}^{\dagger}=\boldsymbol{A}^{\top}(\boldsymbol{A}^{\dagger})^{\top}\boldsymbol{A}^{\dagger}$，并用 $(\boldsymbol{I}-\boldsymbol{B}^{\dagger}\boldsymbol{B})\boldsymbol{A}^{\top}=-(\boldsymbol{I}-\boldsymbol{B}^{\dagger}\boldsymbol{B})\boldsymbol{E}^{\top}$。三项相加即得。 ■

这个估计本身不要求两矩阵同秩，关键是正奇异值有与扰动无关的共同下界。秩增加时这一点做不到：取 $\boldsymbol{A}=\operatorname{diag}(1,0)$ 与 $\boldsymbol{B}_{\varepsilon}=\operatorname{diag}(1,\varepsilon)$，$\|\boldsymbol{B}_{\varepsilon}-\boldsymbol{A}\|_2=\varepsilon\to 0$，而 $\boldsymbol{B}_{\varepsilon}^{\dagger}=\operatorname{diag}(1,1/\varepsilon)$，$\|\boldsymbol{B}_{\varepsilon}^{\dagger}-\boldsymbol{A}^{\dagger}\|_2=1/\varepsilon\to\infty$；新出现的小奇异值带来很大的增益。

用第 3.2.4节的连续性定义，可以把估计与反例合起来表述。在全体秩为 r 的矩阵组成的集合 $\mathcal{M}_r$ 上，若 $\|\boldsymbol{E}\|_2<\sigma_r(\boldsymbol{A})/2$，由 Weyl 界（定理 7.15）两矩阵的正奇异值都不小于 $\sigma_r(\boldsymbol{A})/2$，代入上式得 $\|\boldsymbol{B}^{\dagger}-\boldsymbol{A}^{\dagger}\|_2\le 12\|\boldsymbol{E}\|_2/\sigma_r(\boldsymbol{A})^2$，

所以伪逆在 $\mathcal{M}_r$ 上连续。允许秩增加时，在 $\boldsymbol{A}$ 上加 $t\boldsymbol{u}_{r+1}\boldsymbol{v}_{r+1}^{\top}$ 同样使伪逆差为 $1/t$，伪逆在秩亏矩阵处不连续。

求逆则不同：可逆矩阵附近的矩阵仍可逆，秩不会变，求逆在可逆矩阵集合上连续。两种结论的差别来自定义域。$r < \min(m, d)$ 时 $\mathcal{M}_r$ 不是整个矩阵空间中的开集，也不是某个线性子空间中的开集，第 17章针对这两类集合的微分定义在秩亏处不能直接套用，本部分不展开一般伪逆的微分。

数值秩　实际数据的秩因此要谨慎对待。矩阵改变 $\boldsymbol{E}$ 时，每个奇异值的移动不超过 $\|\boldsymbol{E}\|_2$（式 (7.5)），小于误差尺度的奇异值与零无法区分。给定阈值 $\tau \geq 0$，矩阵中大于 τ 的奇异值个数称为它在阈值 τ 下的**数值秩**（numerical rank）。

取 τ 为数据误差 $\|\tilde{\boldsymbol{A}} - \boldsymbol{A}\|_2$ 的上界时，与观测相容的精确矩阵的秩都不小于数值秩（定理 7.16），而截断 SVD 给出一个秩恰为数值秩、同样相容的矩阵（定理 15.11）。所以阈值要联系误差来源：只有舍入误差时取 $u\sigma_1$ 乘一个维数常数的量级，带测量噪声时按噪声在谱范数下的规模选取。

精确秩是矩阵的代数性质；数据带误差时，能回答的是在给定误差水平下可以可靠辨认多少个方向。奇异值在阈值附近有明显间隔时这个数目稳定，缓慢衰减时它随阈值变化，不能只机械地判断某个计算值是否为零。下一节的正则化正是针对这些难以辨认的方向。

14.2 正则化方法

上一节表明，数据误差沿小奇异值方向被放大 $1/\sigma_i$ 倍。QR 等正交算法只能避免在问题本身的敏感度之外再损失精度，改变不了这种放大。本节换一种做法：通过惩罚系数的大小或舍弃部分方向，主动修改求解目标，用一部分拟合误差换取解的稳定。

两种做法分两小节讨论。岭回归与 Tikhonov 正则化在目标中加入惩罚项，连续地压低敏感方向；谱截断正则化直接舍弃小奇异值方向。每小节先说明目标与它在奇异方向上的作用，再给出计算路线与算例，最后分析误差与代价。由于目标已经改变，算出的是新目标的解，不能把它当作原问题更准确的解。

14.2.1 岭回归与 Tikhonov 正则化

主要思想　对 $\lambda > 0$，岭回归（ridge regression）求解

$$\min_{\boldsymbol{x}} \|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|_2^2 + \lambda\|\boldsymbol{x}\|_2^2. \tag{14.6}$$

第二项惩罚系数的长度：拟合同样好的两个解中，目标偏向长度较小的一个；λ 越大，偏向越强。

惩罚也可以作用在希望压小的量上，例如相邻分量之差。取惩罚矩阵 $\boldsymbol{\Gamma} \in \mathbb{R}^{p\times d}$，目标改为

$$\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|_2^2+\lambda\|\boldsymbol{\Gamma}\boldsymbol{x}\|_2^2,$$

称为Tikhonov 正则化（Tikhonov regularization）[4]。，岭回归是 $\boldsymbol{\Gamma}=\boldsymbol{I}$ 的情形。文献中惩罚矩阵常记作 $\boldsymbol{L}$；本部分的 $\boldsymbol{L}$ 已用于表示矩阵的严格下三角部分（第 11.1节），所以这里改记为 $\boldsymbol{\Gamma}$。

[4] P. C. Hansen, *Regularization Tools: A Matlab Package for Analysis and Solution of Discrete Ill-Posed Problems*, version 4.1, Technical University of Denmark, Mar. 2008

两项平方长度之和等于把两个残差向量上下堆叠后的平方长度：$\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|_2^2+\|\sqrt{\lambda}\,\boldsymbol{\Gamma}\boldsymbol{x}-\boldsymbol{0}\|_2^2$。所以 Tikhonov 正则化是一个**增广最小二乘**（augmented least squares）问题

$$\min_{\boldsymbol{x}}\|\tilde{\boldsymbol{A}}\boldsymbol{x}-\tilde{\boldsymbol{b}}\|_2^2,\qquad \tilde{\boldsymbol{A}}=\begin{bmatrix}\boldsymbol{A}\\ \sqrt{\lambda}\,\boldsymbol{\Gamma}\end{bmatrix},\quad \tilde{\boldsymbol{b}}=\begin{bmatrix}\boldsymbol{b}\\ \boldsymbol{0}\end{bmatrix}. \tag{14.7}$$

在计算上，惩罚只是在原数据下方增加了 p 行，对应的右端为零：每一行要求 $\sqrt{\lambda}$ 倍的某个线性组合 $(\boldsymbol{\Gamma}\boldsymbol{x})_i$ 接近零。由此可以直接读出解的存在性与唯一性。

定理 14.8　Tikhonov 解的存在与唯一　设 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$，$\boldsymbol{\Gamma}\in\mathbb{R}^{p\times d}$，$\lambda>0$。Tikhonov 目标的极小点恰为方程

$$(\boldsymbol{A}^{\top}\boldsymbol{A}+\lambda\boldsymbol{\Gamma}^{\top}\boldsymbol{\Gamma})\boldsymbol{x}=\boldsymbol{A}^{\top}\boldsymbol{b}$$

的解，这样的解总存在；解唯一当且仅当

$$\ker\boldsymbol{A}\cap\ker\boldsymbol{\Gamma}=\{\boldsymbol{0}\}. \tag{14.8}$$

特别地，岭回归对任意 $\boldsymbol{A}$ 都有唯一解。

证明　目标等于增广问题 (14.7)。由第 9.2节，增广残差与 $\tilde{\boldsymbol{A}}$ 的列空间正交的点就是极小点，即正规方程 $\tilde{\boldsymbol{A}}^{\top}\tilde{\boldsymbol{A}}\boldsymbol{x}=\tilde{\boldsymbol{A}}^{\top}\tilde{\boldsymbol{b}}$ 的解；它总存在，且唯一当且仅当 $\ker\tilde{\boldsymbol{A}}=\{\boldsymbol{0}\}$。代入 $\tilde{\boldsymbol{A}}^{\top}\tilde{\boldsymbol{A}}=\boldsymbol{A}^{\top}\boldsymbol{A}+\lambda\boldsymbol{\Gamma}^{\top}\boldsymbol{\Gamma}$ 与 $\tilde{\boldsymbol{A}}^{\top}\tilde{\boldsymbol{b}}=\boldsymbol{A}^{\top}\boldsymbol{b}$ 即得上面的方程。又

$$\boldsymbol{x}^{\top}(\boldsymbol{A}^{\top}\boldsymbol{A}+\lambda\boldsymbol{\Gamma}^{\top}\boldsymbol{\Gamma})\boldsymbol{x}=\|\boldsymbol{A}\boldsymbol{x}\|_2^2+\lambda\|\boldsymbol{\Gamma}\boldsymbol{x}\|_2^2,$$

$\lambda>0$ 时它为零当且仅当 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 且 $\boldsymbol{\Gamma}\boldsymbol{x}=\boldsymbol{0}$，所以 $\ker\tilde{\boldsymbol{A}}=\ker\boldsymbol{A}\cap\ker\boldsymbol{\Gamma}$。岭回归中 $\ker\boldsymbol{I}=\{\boldsymbol{0}\}$。 ∎

一般的 $\boldsymbol{\Gamma}$ 未必满足条件 (14.8)：$\boldsymbol{A}=\boldsymbol{\Gamma}=[\,1\ \ -1\,]$ 时，$(1,1)^{\top}$ 方向既不影响拟合也不受惩罚，无论 λ 多大都定不下两个分量的共同水平。加入惩罚以后，目标中的平方不能去掉：最小化 $\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|_2+\lambda\|\boldsymbol{x}\|_2$ 是另一个问题，不能像无惩罚时那样把残差范数与其平方互换。

奇异方向上的滤波　岭回归的作用可以在奇异方向上逐个看清。设 $\boldsymbol{A}$ 的秩为 r，正奇异值与奇异向量为 $\sigma_i,\boldsymbol{u}_i,\boldsymbol{v}_i$，记 $c_i=\boldsymbol{u}_i^{\top}\boldsymbol{b}$。

定理 14.9　岭回归的滤波因子　设 $\lambda>0$，$\boldsymbol{x}_\lambda$ 为岭回归 (14.6) 的解，则

$$\boldsymbol{x}_\lambda=\sum_{i=1}^{r} f_i\,\frac{c_i}{\sigma_i}\,\boldsymbol{v}_i,\qquad f_i=\frac{\sigma_i^2}{\sigma_i^2+\lambda}\in(0,1). \tag{14.9}$$

每个方向的增益 $\sigma_i/(\sigma_i^2+\lambda)$ 不超过 $1/(2\sqrt{\lambda})$。残差平方为

$$\|\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_\lambda\|_2^2=\|(\boldsymbol{I}-\boldsymbol{A}\boldsymbol{A}^{\dagger})\boldsymbol{b}\|_2^2+\sum_{i=1}^{r}(1-f_i)^2c_i^2,$$

它随 λ 增大而不减，$\|\boldsymbol{x}_\lambda\|_2$ 随 λ 增大而不增，且 $\lambda\to0^{+}$ 时 $\boldsymbol{x}_\lambda\to\boldsymbol{A}^{\dagger}\boldsymbol{b}$。

证明　把右奇异向量补成 $\mathbb{R}^d$ 的标准正交基 $\boldsymbol{v}_1,\dots,\boldsymbol{v}_d$，令 $\boldsymbol{x}=\sum_i z_i\boldsymbol{v}_i$。由 $\boldsymbol{A}\boldsymbol{v}_i=\sigma_i\boldsymbol{u}_i$（$i\le r$）与 $\boldsymbol{A}\boldsymbol{v}_i=\boldsymbol{0}$（$i>r$），并把 $\boldsymbol{b}$ 分成列空间内的 $\sum_{i\le r}c_i\boldsymbol{u}_i$ 与正交补中的 $(\boldsymbol{I}-\boldsymbol{A}\boldsymbol{A}^{\dagger})\boldsymbol{b}$，目标化为

$$\|(\boldsymbol{I}-\boldsymbol{A}\boldsymbol{A}^{\dagger})\boldsymbol{b}\|_2^2+\sum_{i=1}^{r}\bigl[(\sigma_iz_i-c_i)^2+\lambda z_i^2\bigr]+\lambda\sum_{i>r}z_i^2.$$

各坐标互不耦合，可以逐个配方：

$$(\sigma_iz_i-c_i)^2+\lambda z_i^2=(\sigma_i^2+\lambda)\Bigl(z_i-\frac{\sigma_ic_i}{\sigma_i^2+\lambda}\Bigr)^2+\frac{\lambda c_i^2}{\sigma_i^2+\lambda},$$

所以 $z_i=\sigma_ic_i/(\sigma_i^2+\lambda)$（$i\le r$），而零空间坐标只受惩罚，取 $z_i=0$（$i>r$）。这就是式 (14.9)。

增益界来自 $\sigma_i^2+\lambda\ge2\sigma_i\sqrt{\lambda}$。由 $\boldsymbol{A}\boldsymbol{x}_\lambda=\sum_i f_ic_i\boldsymbol{u}_i$，残差在 $\operatorname{range}\boldsymbol{A}$ 内的分量为 $\sum_i(1-f_i)c_i\boldsymbol{u}_i$，与列空间外的分量正交，得到残差公式。$1-f_i=\lambda/(\sigma_i^2+\lambda)$ 随 λ 增大，f_i/σ_i 随 λ 减小，故两个单调性成立；$\lambda\to0^{+}$ 时 $f_i\to1$，极限为第 9.4节的 $\boldsymbol{A}^{\dagger}\boldsymbol{b}$。 ■

伪逆的增益 $1/\sigma_i$ 被换成有界的 $\sigma_i/(\sigma_i^2+\lambda)$，不再随 $\sigma_i\to0$ 爆炸。与最小范数解相比，每个方向多乘了一个**滤波因子**（filter factor）f_i：$\sigma_i^2\gg\lambda$ 的方向几乎不变，$\sigma_i^2\ll\lambda$ 的方向被压低，转折点在 $\sigma_i=\sqrt{\lambda}$，那里 $f_i=1/2$、

增益达到峰值。图 14.2画出了两种 λ 下的滤波因子与增益：λ 每增大一百倍，转折点就向大奇异值移动一个数量级，增益峰值降为十分之一。

代价是拟合改变了，偏差随之引入。λ 太小，噪声沿小奇异值方向放大；太大，真实信号也被压掉。合适的参数依赖数据误差与任务目标，例如已知误差规模 ϵ 时取使 $\|\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_\lambda\|_2 \approx \epsilon$ 的 λ，或在留出的数据上检验预测效果；不能只因某个参数使计算容易就宣称它最合适。

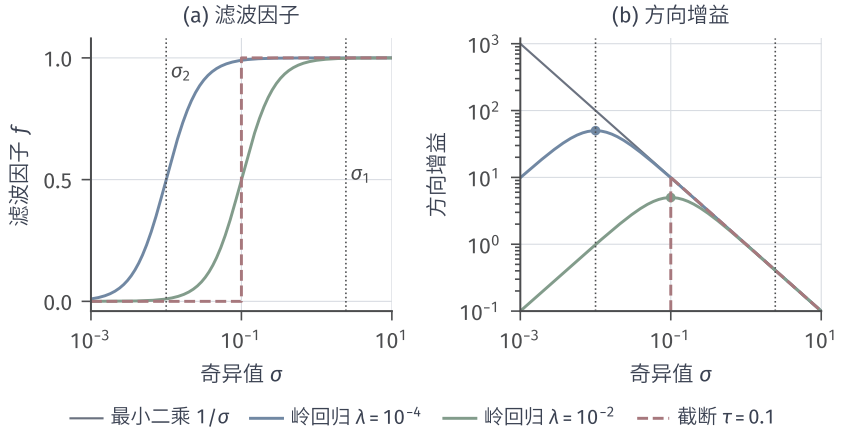


图 14.2　岭回归与截断 SVD 沿奇异方向的作用。(a) 滤波因子：岭回归 $f=\sigma^2/(\sigma^2+\lambda)$ 在 $\sigma=\sqrt{\lambda}$ 处取 $1/2$ 并连续过渡，截断 SVD 在阈值 τ 处由 0 跳到 1。(b) 方向增益：最小二乘为 $1/\sigma$，岭回归为 $\sigma/(\sigma^2+\lambda)$，圆点是峰值 $1/(2\sqrt{\lambda})$；截断后小于 τ 的方向增益为零。竖虚线是示例 14.13中矩阵的两个奇异值。

算法实现与算例　这里要区分两件事。第 10.7节的正交算法改善的是同一问题的计算过程；正则化则主动修改了问题，以控制敏感性。计算路线有三条。

第一条是增广 QR，适用于任意 $\boldsymbol{\Gamma}$。输入 $\boldsymbol{A},\boldsymbol{b},\boldsymbol{\Gamma},\lambda$，先核对 $\boldsymbol{A}$ 与 $\boldsymbol{\Gamma}$ 的列数相同、$\boldsymbol{b}$ 的长度等于 $\boldsymbol{A}$ 的行数，再构造 $\tilde{\boldsymbol{A}}$ 与 $\tilde{\boldsymbol{b}}$。若条件 (14.8)成立，$\tilde{\boldsymbol{A}}$ 满列秩，对它作 Householder QR，$\tilde{\boldsymbol{A}}=\boldsymbol{Q}\boldsymbol{R}$，算出 $\boldsymbol{Q}^{\mathsf{T}}\tilde{\boldsymbol{b}}$，再解上三角方程 $\boldsymbol{R}\boldsymbol{x}=\boldsymbol{Q}^{\mathsf{T}}\tilde{\boldsymbol{b}}$。若条件不成立，增广问题的解不唯一，要先按第 9章的准则另选代表，例如对 $\tilde{\boldsymbol{A}}$ 作 SVD 取最小范数解。退出时报告原残差 $\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}$、惩罚量 $\|\boldsymbol{\Gamma}\boldsymbol{x}\|_2$，并核验增广正规残差 $\boldsymbol{A}^{\mathsf{T}}(\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x})-\lambda\boldsymbol{\Gamma}^{\mathsf{T}}\boldsymbol{\Gamma}\boldsymbol{x}$ 接近零。

第二条只用于 $\boldsymbol{\Gamma}=\boldsymbol{I}$：先作一次 SVD，算出 $c_i=\boldsymbol{u}_i^{\mathsf{T}}\boldsymbol{b}$，此后每个 λ 只需按式 (14.9)乘滤波因子，扫描多个参数时最省。第三条对 $\boldsymbol{A}^{\mathsf{T}}\boldsymbol{A}+\lambda\boldsymbol{\Gamma}^{\mathsf{T}}\boldsymbol{\Gamma}$ 作 Cholesky 分解（第 10.2节），再依次前代、回代；推导中的这个正规矩阵并不是必须显式形成的对象，下面的算法分析会说明这条路线何时可靠。大型问题还可以把 LSQR（第 12.9节）用于增广问题 (14.7)。

示例 14.10　增广 QR 求岭回归　取教学例 $\boldsymbol{A}=\operatorname{diag}(3,1)$，$\boldsymbol{b}=(3,1)^{\top}$，$\boldsymbol{\Gamma}=\boldsymbol{I}$，$\lambda=1$。无惩罚时方程相容，解为 $(1,1)^{\top}$。增广矩阵与右端为

$$\tilde{\boldsymbol{A}}=\begin{bmatrix}3&0\\0&1\\1&0\\0&1\end{bmatrix},\qquad \tilde{\boldsymbol{b}}=\begin{bmatrix}3\\1\\0\\0\end{bmatrix}.$$

$\tilde{\boldsymbol{A}}$ 的两列 $(3,0,1,0)^{\top}$ 与 $(0,1,0,1)^{\top}$ 已经正交，长度分别为 $\sqrt{10}$ 与 $\sqrt{2}$，所以 QR 分解只需把两列单位化：$\boldsymbol{R}=\operatorname{diag}(\sqrt{10},\sqrt{2})$，$\boldsymbol{Q}$ 的两列为 $(3,0,1,0)^{\top}/\sqrt{10}$ 与 $(0,1,0,1)^{\top}/\sqrt{2}$。于是

$$\boldsymbol{Q}^{\top}\tilde{\boldsymbol{b}}=\Big(\frac{9}{\sqrt{10}},\frac{1}{\sqrt{2}}\Big)^{\top},\qquad \boldsymbol{x}_{\lambda}=\boldsymbol{R}^{-1}\boldsymbol{Q}^{\top}\tilde{\boldsymbol{b}}=\Big(\frac{9}{10},\frac{1}{2}\Big)^{\top}.$$

逐项核验：$\boldsymbol{A}\boldsymbol{x}_{\lambda}-\boldsymbol{b}=(27/10-3,\,1/2-1)^{\top}=(-3/10,-1/2)^{\top}$，$\boldsymbol{A}^{\top}(\boldsymbol{A}\boldsymbol{x}_{\lambda}-\boldsymbol{b})+\lambda\boldsymbol{x}_{\lambda}=(-9/10+9/10,\,-1/2+1/2)^{\top}=\boldsymbol{0}$，增广正规条件成立。按滤波因子公式，$f_1=9/10$、$f_2=1/2$，同样得到 $(9/10,1/2)^{\top}$：奇异值较小的第二个方向被压掉一半。

原方程本来有精确解 $(1,1)^{\top}$，算法得到的却是 $(9/10,1/2)^{\top}$，残差不为零。这不是计算误差，而是新目标的解：惩罚项改变了要解的问题。

示例 14.11　直线拟合的岭回归　沿用示例 9.4的 $\boldsymbol{A}=\left[\begin{smallmatrix}1&0\\1&1\\1&2\end{smallmatrix}\right]$ 与 $\boldsymbol{b}=(1,2,2)^{\top}$，取 $\lambda=1$，走 Cholesky 路线。正则化后的方程为

$$\begin{bmatrix}4&3\\3&6\end{bmatrix}\boldsymbol{x}=\begin{bmatrix}5\\6\end{bmatrix},$$

分解得 $l_{1,1}=2$，$l_{2,1}=1.5$，$l_{2,2}=\sqrt{6-1.5^2}\approx 1.9365$。前代得 $y_1=2.5$，$y_2=(6-1.5\times 2.5)/1.9365\approx 1.1619$；回代得 $x_2=1.1619/1.9365=0.6$，$x_1=(2.5-1.5\times 0.6)/2=0.8$。于是 $\boldsymbol{x}_{\lambda}=(0.8,0.6)^{\top}$，拟合值 $(0.8,1.4,2.0)^{\top}$，残差 $(0.2,0.6,0)^{\top}$。

核验正则化的正规残差：$\boldsymbol{A}^{\top}\boldsymbol{r}=(0.8,0.6)^{\top}$ 恰等于 $\lambda\boldsymbol{x}_{\lambda}$，两者之差为零。与最小二乘解 $(7/6,1/2)^{\top}$ 相比，残差平方由 $1/6$ 增至 0.4，解的长度由 1.269 降为 1。按 SVD 路线，$\sigma_1^2\approx 7.162$、$\sigma_2^2\approx 0.838$，滤波因子为 $f_1\approx 0.877$、$f_2\approx 0.456$：σ_2^2 与 λ 相当，第二个方向被压掉约一半。

算法分析 Cholesky 路线的条件数是 $\kappa_2(\tilde{\boldsymbol{A}})^2$。岭回归中 $\kappa_2(\tilde{\boldsymbol{A}}) = \big((\sigma_1^2+\lambda)/(\sigma_d^2+\lambda)\big)^{1/2} \le (1+\sigma_1^2/\lambda)^{1/2}$（$\sigma_d$ 为第 d 个奇异值，秩亏时为零），即使 $\boldsymbol{A}$ 秩亏也有界。所以只在 λ 不太小、$(1+\sigma_1^2/\lambda)u \ll 1$ 时，这条路线与增广 QR 同样可靠。

无论哪条路线，结果都要回到正则化目标核验：分别报告拟合误差 $\|\boldsymbol{A}\boldsymbol{x}_\lambda-\boldsymbol{b}\|_2$ 与惩罚大小 $\|\boldsymbol{\Gamma}\boldsymbol{x}_\lambda\|_2$，正规残差应检查 $\boldsymbol{A}^{\top}(\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_\lambda)-\lambda\boldsymbol{\Gamma}^{\top}\boldsymbol{\Gamma}\boldsymbol{x}_\lambda$，而不是原问题的 $\boldsymbol{A}^{\top}\boldsymbol{r}$。

14.2.2 谱截断正则化

主要思想 从第 5章的 SVD 出发，先在奇异坐标中写出最小范数最小二乘解：

$$\boldsymbol{A}^{\dagger}\boldsymbol{b} = \sum_{i=1}^{r} \frac{\boldsymbol{u}_i^{\top}\boldsymbol{b}}{\sigma_i}\,\boldsymbol{v}_i .$$

右端在第 i 个左奇异方向上的误差被放大 $1/\sigma_i$ 倍。若误差预算表明某些方向的观测分量 $c_i = \boldsymbol{u}_i^{\top}\boldsymbol{b}$ 主要是噪声，就不应在这些方向上反演。谱截断正则化因此只在可靠的奇异方向上恢复系数。

具体地，给定阈值 τ，取保留集 $J=\{i:\sigma_i>\tau\}$；也可以事先指定保留最大的 k 个正奇异值。奇异值按降序排列，所以 $J=\{1,\dots,k\}$，$k=|J|$。令

$$\boldsymbol{x}_k = \sum_{i=1}^{k} \frac{\boldsymbol{u}_i^{\top}\boldsymbol{b}}{\sigma_i}\,\boldsymbol{v}_i, \qquad 1\le k\le r.$$

这种做法称为**截断 SVD**（truncated SVD）求解。

它是一个限制在子空间上的最小二乘解。把系数限制在 $\operatorname{span}\{\boldsymbol{v}_1,\dots,\boldsymbol{v}_k\}$ 中，写 $\boldsymbol{x}=\sum_{i\le k} z_i\boldsymbol{v}_i$，则

$$\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|_2^2 = \sum_{i=1}^{k}(\sigma_i z_i - c_i)^2 + \sum_{i=k+1}^{r} c_i^2 + \|(\boldsymbol{I}-\boldsymbol{A}\boldsymbol{A}^{\dagger})\boldsymbol{b}\|_2^2 .$$

只有第一项依赖 $\boldsymbol{z}$，取 $z_i=c_i/\sigma_i$ 使它为零，就得到 $\boldsymbol{x}_k$。被舍弃方向上的观测分量 $c_{k+1},\dots,c_r$ 无法再被拟合，全部转入残差。

用矩阵写，$\boldsymbol{x}_k=\boldsymbol{A}_k^{\dagger}\boldsymbol{b}$，其中 $\boldsymbol{A}_k=\sum_{i\le k}\sigma_i\boldsymbol{u}_i\boldsymbol{v}_i^{\top}$ 是第 15.3节的截断 SVD（式 (15.6)），$\boldsymbol{A}_k^{\dagger}\boldsymbol{b}$ 是以 $\boldsymbol{A}_k$ 代替 $\boldsymbol{A}$ 后的最小范数最小二乘解。$\boldsymbol{A}_k$ 作为矩阵的最佳低秩性质在第 15章讨论；它与截断求解共用同一个分解，目的却不同：低秩逼近要重建矩阵，截断求解要从带误差的观测中稳定地恢复输入。

算法实现与算例 先求经济型 SVD，并算出 $\boldsymbol{c}=\boldsymbol{U}^{\top}\boldsymbol{b}$，即 $c_i=\boldsymbol{u}_i^{\top}\boldsymbol{b}$。然后按保留规则逐项设置 $z_i=c_i/\sigma_i$（$i\in J$）或 $z_i=0$（$i\notin J$），最后计算 $\boldsymbol{x}_k=\boldsymbol{V}\boldsymbol{z}$。所有除法只在保留的正奇异值上执行。由 $\boldsymbol{A}\boldsymbol{x}_k=\sum_{i\le k}c_i\boldsymbol{u}_i$ 可以直接读出

拟合值，残差不必再乘 $\boldsymbol{A}$ 就能得到；换一个阈值只需增减和式中的项。退出时核验原残差，并检查限制子空间中的正规条件 $\boldsymbol{v}_i^{\top}\boldsymbol{A}^{\top}(\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_k)=0$ $(i\le k)$。

示例 14.12　对角矩阵的谱截断　取 $\boldsymbol{A}=\operatorname{diag}(1,1/100)$，真实系数 $\boldsymbol{x}_{\text{true}}=(1,1)^{\top}$，无噪声的观测为 $(1,1/100)^{\top}$；设第二个观测带误差 $2/100$，实际得到 $\boldsymbol{b}=(1,3/100)^{\top}$。这里 $\sigma_1=1$，$\sigma_2=1/100$，奇异向量就是坐标向量，$c_1=1$，$c_2=3/100$。

不截断时 $\boldsymbol{x}=(c_1/\sigma_1,\,c_2/\sigma_2)^{\top}=(1,3)^{\top}$：第二个方向把误差 $2/100$ 放大了一百倍。取 $\tau=1/10$，只保留 σ_1，得 $\boldsymbol{x}_1=(1,0)^{\top}$，原残差 $\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_1=(0,3/100)^{\top}$，正是被舍弃的观测分量。

两种恢复的误差范数分别为 $\|(1,3)^{\top}-(1,1)^{\top}\|_2=2$ 与 $\|(1,0)^{\top}-(1,1)^{\top}\|_2=1$，截断的误差较小。但这个改善是以丢掉真实的第二分量为代价的：若真值的第二分量很大而噪声很小，截断反而更差。不能从一个算例推断任意真值和噪声下截断都更好，下面的误差分解说明了一般情形。

示例 14.13　近共线设计的截断求解　设计矩阵的两列为 $(1,1,1)^{\top}$ 与 $(1,1.01,0.99)^{\top}$，观测 $\boldsymbol{b}=(1,1.1,0.9)^{\top}$。SVD 给出 $\sigma_1\approx 2.449$、$\sigma_2\approx 0.0100$，$\boldsymbol{v}_1\approx(1,1)^{\top}/\sqrt{2}$，$\boldsymbol{v}_2\approx(1,-1)^{\top}/\sqrt{2}$；投影系数 $c_1\approx 1.733$，$c_2\approx -0.134$。

截断只保留大于阈值的奇异值。取 $\tau=0.1$，只有 σ_1 超过阈值，$k=1$。于是 $\boldsymbol{x}_1=(c_1/\sigma_1)\boldsymbol{v}_1\approx 0.7073\,\boldsymbol{v}_1\approx(0.50,0.50)^{\top}$。$\boldsymbol{b}$ 在列空间内，残差全部来自舍弃的方向，$\|\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_1\|_2=|c_2|\approx 0.134$；正规残差 $\boldsymbol{A}^{\top}(\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_1)=\sigma_2 c_2\boldsymbol{v}_2$ 的长度约为 0.0013，不为零，$\boldsymbol{x}_1$ 不是原问题的最小二乘解。若不截断，第二个方向贡献 $(c_2/\sigma_2)\boldsymbol{v}_2\approx -13.4\,\boldsymbol{v}_2$，得到精确拟合的 $(-9,10)^{\top}$。两者对照，截断以约 0.134 的残差为代价，把一对此增彼减的大系数换成了两个接近 0.5 的系数。

算法分析　设观测由真实输入加噪声得到。截断解的误差与拟合损失都可以按奇异方向分开。

定理 14.14　截断 SVD 的误差分解　设 $\boldsymbol{b}=\boldsymbol{A}\boldsymbol{x}_{\text{true}}+\boldsymbol{e}$，$\boldsymbol{x}_{\text{true}}\in\operatorname{range}\boldsymbol{A}^{\top}$，$1\le k\le r$。则

$$\boldsymbol{x}_k-\boldsymbol{x}_{\text{true}}=\sum_{i=1}^{k}\frac{\boldsymbol{u}_i^{\top}\boldsymbol{e}}{\sigma_i}\boldsymbol{v}_i-\sum_{i=k+1}^{r}(\boldsymbol{v}_i^{\top}\boldsymbol{x}_{\text{true}})\boldsymbol{v}_i,$$

两项正交，第一项的长度不超过 $\|\boldsymbol{e}\|_2/\sigma_k$。此外

$$\|\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_k\|_2^2=\|\boldsymbol{b}-\boldsymbol{A}\hat{\boldsymbol{x}}\|_2^2+\sum_{i=k+1}^{r}c_i^2,\qquad \boldsymbol{A}^{\top}(\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_k)=\sum_{i=k+1}^{r}\sigma_i c_i\boldsymbol{v}_i,$$

其中 $\hat{\boldsymbol{x}}$ 为任一最小二乘解。

证明 由 $c_i=\sigma_i\boldsymbol{v}_i^{\top}\boldsymbol{x}_{\text{true}}+\boldsymbol{u}_i^{\top}\boldsymbol{e}$，$\boldsymbol{x}_k=\sum_{i\le k}(\boldsymbol{v}_i^{\top}\boldsymbol{x}_{\text{true}}+\boldsymbol{u}_i^{\top}\boldsymbol{e}/\sigma_i)\boldsymbol{v}_i$；而 $\boldsymbol{x}_{\text{true}}=\sum_{i\le r}(\boldsymbol{v}_i^{\top}\boldsymbol{x}_{\text{true}})\boldsymbol{v}_i$，相减即得误差式。两项落在互相正交的 $\boldsymbol{v}_i$ 上；第一项长度的平方为 $\sum_{i\le k}(\boldsymbol{u}_i^{\top}\boldsymbol{e})^2/\sigma_i^2\le\|\boldsymbol{e}\|_2^2/\sigma_k^2$。残差 $\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_k=(\boldsymbol{I}-\boldsymbol{A}\boldsymbol{A}^{\dagger})\boldsymbol{b}+\sum_{i>k}c_i\boldsymbol{u}_i$，两部分正交，前者就是最小二乘残差；再用 $\boldsymbol{A}^{\top}\boldsymbol{u}_i=\sigma_i\boldsymbol{v}_i$ 与 $\boldsymbol{A}^{\top}(\boldsymbol{I}-\boldsymbol{A}\boldsymbol{A}^{\dagger})=\boldsymbol{0}$ 得正规残差。 ■

第一项是保留方向的噪声放大，界由 σ_k 而不是 σ_r 决定；第二项是舍弃方向上真实输入的全部损失，这就是截断引入的偏差。在例 14.12中，不截断（$k=r$）时没有舍弃项，误差 $(0,2)^{\top}$ 全部是噪声放大；截断后误差 $(0,-1)^{\top}$ 全部是偏差。拟合的代价是残差平方多出被舍弃的 c_i^2；正规残差只落在被舍弃的方向上，所以限制子空间中的正规条件成立。主要计算代价是一次 SVD，为 $O(md^2)$ 量级。

与岭回归的比较 岭回归连续地压低小奇异值方向，截断则把滤波因子直接取成 1（$i\le k$）或 0（$i>k$），两者在图 14.2中分别是光滑曲线与阶梯。下面的例子在同一组数据上比较两者。

示例 14.15　岭回归与截断 SVD 的比较 沿用示例 14.13的数据，再把 $\boldsymbol{b}$ 改为 $(1,1.11,0.89)^{\top}$，这个扰动几乎全部落在 $\boldsymbol{u}_2$ 上。下表前两列是原观测下各方法的解与残差长度，最后一列是改动观测后系数的变化与观测的变化之比：

方法	$\boldsymbol{x}$	$\|\boldsymbol{r}\|_2$	$\|\Delta\boldsymbol{x}\|_2/\|\Delta\boldsymbol{b}\|_2$
最小二乘	$(-9,\,10)^{\top}$	0	100
$\lambda=10^{-4}$	$(-4.25,\,5.25)^{\top}$	0.067	50
$\lambda=10^{-2}$	$(0.41,\,0.59)^{\top}$	0.133	0.99
$k=1$	$(0.50,\,0.50)^{\top}$	0.134	0.002

响应比就是第二个方向的增益：最小二乘为 $1/\sigma_2=100$，岭回归为 $\sigma_2/(\sigma_2^2+\lambda)$，截断后为零，剩下的 0.002 来自扰动在 $\boldsymbol{u}_1$ 上的微小分量。精确拟合的大系数全部来自第二个方向；系数越稳定，残差越大，$\lambda=10^{-2}$ 的岭回归与 $k=1$ 的截断已经很接近。

奇异值在某处明显下降时，截断位置有自然的选择，截断把可信与不可信的方向分得最清楚；奇异值缓慢衰减、没有间隔时，连续衰减的岭回归更平稳。阈值应联系噪声规模、截断处的奇异值间隔和任务目标。取 τ 为数据误差的估计，就是只在第 14.1.4节意义下可辨认的方向上反演；它不等同于按机器精度判定精确秩，只有数据仅含舍入误差时两者才一致。

与低秩逼近的边界　截断求解与第 15.3节的结论有明确的边界。$\boldsymbol{A}_k$ 在谱范数与 Frobenius 范数下是最佳秩 k 重建（定理 15.11），但由定理 14.14的正规残差，除非被舍弃的 c_i 全为零，$\boldsymbol{x}_k$ 不是原问题的最小二乘解。矩阵逼近的最优性又不涉及 $\boldsymbol{x}_{\text{true}}$ 与 $\boldsymbol{e}$，更不能由它断言 $\boldsymbol{x}_k$ 最接近未知的真实输入。

所以截断求解要同时说明保留了哪些方向、噪声水平多大、允许多大的拟合损失。保留的方向本身是否可靠，还要看截断处的间隔 $\sigma_k - \sigma_{k+1}$：间隔很小时，扰动可能使前 k 个奇异方向明显偏转，第 7.2.3节的奇异值与子空间扰动界可以用来判断。

14.3　求解方法的比较与选择

求解目标（第 9章）、各类算法（第 10—13章）与误差标准（第 14.1节）都已建立，本节把前面的方法放回同一组问题中比较。先确认目标是精确求解、普通或加权最小二乘、最小范数还是正则化，再按矩阵结构、数据访问、资源和精度选择计算路线。

比较的是达到相同要求的总成本；正则化与截断（第 14.2节）已经改变了目标，它们的系数较小、成本较低，不能直接视为把原问题解得更准确。

14.3.1　求解目标与方法适用性

三个目标要分开：相容方程 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$，一般最小二乘 $\min_{\boldsymbol{x}} \|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|_2$，以及在多个解中选出最小范数解。相容方程的最小二乘最优残差为零，两者在这里重合；不相容时最小二乘要求的是 $\boldsymbol{A}^{\mathsf{T}}\boldsymbol{r} = \boldsymbol{0}$，原残差停在一个正的长度上，所以不能把所有算法都按 $\|\boldsymbol{r}\| \to 0$ 判断。最小范数还要求解不含 $\ker \boldsymbol{A}$ 的分量，这是第 9.3节的额外选解条件。所以原残差为零、正规残差为零与排除零空间分量是三种不同的验收要求。

满列秩时，最小二乘解是正规方程 $\boldsymbol{A}^{\mathsf{T}}\boldsymbol{A}\boldsymbol{x} = \boldsymbol{A}^{\mathsf{T}}\boldsymbol{b}$ 的唯一解，而 $\boldsymbol{A}^{\mathsf{T}}\boldsymbol{A}$ 对称正定，于是矩形问题可以转成对称正定方程，调用 Cholesky、CG 或满足收敛条件的定常迭代。

这种转换有代价。显式形成 $\boldsymbol{A}^{\mathsf{T}}\boldsymbol{A}$ 时，稀疏矩阵可能产生大量填充，条件数变为 $\kappa_2(\boldsymbol{A})^2$，形成过程的舍入还可能丢掉有用的信息（第 14.1.3节）；

不显式形成时，每次作用 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 仍需一次 $\boldsymbol{A}$ 乘法和一次 $\boldsymbol{A}^{\top}$ 乘法。秩亏时正规矩阵只是半正定，正定算法的唯一性与收敛保证不能照搬。

另一种转换保留残差作为未知量：把 $\boldsymbol{r}+\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 与 $\boldsymbol{A}^{\top}\boldsymbol{r}=\boldsymbol{0}$ 合写成一个方阵方程。它的性质决定了能用哪些方法求解。

定理 14.16　最小二乘的增广方程　设 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$ 满列秩，则方程

$$\begin{bmatrix} \boldsymbol{I}_m & \boldsymbol{A} \\ \boldsymbol{A}^{\top} & \boldsymbol{0} \end{bmatrix}\begin{bmatrix} \boldsymbol{r} \\ \boldsymbol{x} \end{bmatrix}=\begin{bmatrix} \boldsymbol{b} \\ \boldsymbol{0} \end{bmatrix}$$

有唯一解，$\boldsymbol{x}$ 为最小二乘解，$\boldsymbol{r}$ 为相应残差；其系数矩阵对称、可逆且不定。

证明　第一块行给出 $\boldsymbol{r}=\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}$，第二块行就是正规方程 $\boldsymbol{A}^{\top}(\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x})=\boldsymbol{0}$，所以解与最小二乘解一一对应。对称性显然。若系数矩阵作用于 $(\boldsymbol{r};\boldsymbol{x})$ 得零，则 $\boldsymbol{r}=-\boldsymbol{A}\boldsymbol{x}$ 且 $\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$，满列秩时只能 $\boldsymbol{x}=\boldsymbol{0}$、$\boldsymbol{r}=\boldsymbol{0}$，故可逆。取 $(\boldsymbol{u};\boldsymbol{0})$，$\boldsymbol{u}\neq\boldsymbol{0}$，二次型为 $\|\boldsymbol{u}\|_2^2>0$；取 $(-\boldsymbol{A}\boldsymbol{x};\boldsymbol{x})$，$\boldsymbol{x}\neq\boldsymbol{0}$，二次型为 $-\|\boldsymbol{A}\boldsymbol{x}\|_2^2<0$，故不定。 ■

因此满列秩最小二乘也可以用分块 $\mathrm{LDL}^{\top}$（第 10.3节）或 MINRES（第 12.5节）处理，但不能用 Cholesky 或 CG。这一转换保留了 $\boldsymbol{A}$ 的稀疏结构，代价是未知量从 d 个增加到 $m+d$ 个，存储和预条件都要按新的分块结构设计，并非免费的计算步骤。

下文用三种说法区分方法与目标的关系。“直接适用”指方法使用原问题的目标和数据，例如 QR、SVD 与 LSQR 直接处理矩形最小二乘。“需转换”指先改变方程的表示，例如经正规方程或增广方程变成方阵方程。“需扩展版本”指要修改算法本身才能处理秩亏、不相容或最小范数的要求，例如扩展 Kaczmarz 相对标准 Kaczmarz。能写出一种迭代公式，不等于已经满足了它的收敛条件。

14.3.2 矩阵条件

目标确定以后再看矩阵：方阵还是长方矩阵，是否对称、正定，秩是否完全，稠密还是稀疏，能否取得 $\boldsymbol{A}^{\top}\boldsymbol{u}$ 或单独一行。表 14.1按这些条件核对每种方法需要什么输入。表中的迭代法按第 11—13章建立的基本版本比较，不能从某一行的限制推出所有同名算法的扩展都不适用。

表中“需转换”时，要重新检查转换后系统的结构、条件数、零空间和误差度量；“直接”也不意味着可以省去预条件、停止检验或退化处理。

方法	直接求解线性方程的主要条件	对一般不相容最小二乘的适用方式	需要特别核对的条件
LU（10.1）	非奇异方阵，采用适当主元策略	需构造相应方程；普通消元不自动保留原残差的最小二乘目标	填充、主元增长与分解复用
Cholesky（10.2）	实对称正定方阵	满列秩时可用于正规方程	正规矩阵的条件数、秩亏和形成误差
分块 $LDL^{\top}$（10.3）	实对称非奇异方阵，可含不定性	可用于满足可解条件的对称增广方程	对称主元块、增广规模与预条件
Schur 补（10.4）	被消去的块可逆，约化系统满足相应可解条件	可用于已有分块系统，不自动定义原始最小二乘目标	被消块与 Schur 补的条件、形成成本和回代
Woodbury（10.5）	已有可复用的可逆基矩阵求解器，更新秩较低，小系统可逆	可更新符合相应条件的方程，不直接处理任意不相容矩形问题	基矩阵分解复用、小系统敏感性与更新后的原残差
正规方程法（10.6）	相容方程可转为 $\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{x}=\boldsymbol{A}^{\top}\boldsymbol{b}$，但可能舍弃原有的有利结构	满列秩时采用 Cholesky；秩亏须改变求解路线	Gram 矩阵的形成成本、条件数平方和正定性
QR（10.7）	相容问题按秩与形状选取 QR 或转置 QR 路线	直接适用；满列秩时得到唯一解	秩亏时需秩揭示与额外处理，基本 QR 不自动给最小范数解
SVD（10.8）	可处理任意形状与秩的相容方程	直接适用，并可选取最小范数解	分解代价及小奇异值的误差放大
Richardson（11.2）	固定步长使 $\rho(\boldsymbol{I}-\alpha\boldsymbol{A})<1$；正定情形有明确的步长区间	需转换，并重新选择步长	谱界、缩放及达到目标精度的总成本
Jacobi（11.3）	对角元非零且迭代矩阵谱半径小于 1	需转换，并重新检查收敛	对称正定本身不保证普通 Jacobi 收敛
Gauss–Seidel、SOR（11.4、11.5）	对角元非零与各自的收敛条件；正定情形另有充分保证	需转换，并检查参数与结构	更新顺序、松弛参数和并行性
SSOR（11.6）	第 11章要求实对称正定矩阵且 $0<\omega<2$	需转换；满列秩的正规方程满足正定结构	每轮双向扫掠，不能与单向方法只按轮数比较
CG（12.2）	实对称正定方阵	可经正规方程使用，不是直接的矩形算法	正定性、条件数，以及预条件是否保持内积结构
MINRES（12.5）	第 12章以实对称非奇异方阵为主，允许不定	不是通用矩形算法；可经合适的对称系统转换	对称结构与停止条件；奇异时的最小范数问题需另论
GMRES（12.4）	一般非奇异方阵，无需对称	可经方阵系统转换，标准版本不直接处理长方矩阵	重启停滞、基的存储和预条件后的残差
BiCG（12.6）	一般非奇异方阵，能施加 $\boldsymbol{A}$ 和 $\boldsymbol{A}^{\top}$	需转换，不是通用的矩形算法	双正交关系和递推失效
BiCGSTAB（12.7）	一般非奇异方阵，通常只需施加 $\boldsymbol{A}$	需转换，不是通用的矩形算法	递推分母、局部稳定步骤与不规则收敛
LSQR（12.9）	可直接用于相容方程，允许长方或秩亏	直接适用，需能计算 $\boldsymbol{A}\boldsymbol{v}$ 与 $\boldsymbol{A}^{\top}\boldsymbol{u}$	初值、基的正交性、停止条件及最小范数要求
LSMR（12.10）	可直接用于相容方程，允许长方或秩亏	直接适用，重点控制正规残差	同时检查原残差与 $\boldsymbol{A}^{\top}\boldsymbol{r}$，不以某一个量概括全部误差
标准 Kaczmarz（13.1）	相容系统及满足要求的行访问规则	不保证求出不相容问题的最小二乘解	零行、行的选择、初值的零空间分量与循环现象

续下页

表 14.1（续）

方法	直接求解线性方程的主要条件	对一般不相容最小二乘的适用方式	需要特别核对的条件
扩展 Kaczmarz（13.2）	可用于相容系统	经行列校正处理不相容最小二乘	需要列访问或对应的校正操作，额外成本与初值条件

表 14.1　各方法的矩阵条件与适用方式。方法名后括号内为所在节。

14.3.3 计算开销与收敛速度

总开销拆成准备、每步计算、迭代步数、额外存储和通信五部分。设 $\boldsymbol{A}$ 有 q 个非零元素，一次矩阵向量积通常需要 $O(q)$ 次算术运算，向量的内积与线性组合需要与维数同阶的运算。

Kaczmarz 的一步只访问一行，不能把它的步数与一次完整矩阵向量积的步数直接比较，应同时报告遍历全部数据的次数或总算术量。

对稠密 d 阶方阵，LU 的分解约需 $\frac{2}{3}d^3$ 次运算，Cholesky 与分块 $\mathrm{LDL}^{\mathsf{T}}$ 利用对称性约为它的一半；分解之后，每个右端只需两次三角求解，约 $2d^2$ 次运算，所以多右端问题应复用分解。

对 $m \geq d$ 的稠密矩形矩阵，Householder QR 约需 $2md^2 - \frac{2}{3}d^3$ 次运算，经济型 SVD 也是 $O(md^2)$ 量级，但常数更大、需要迭代，换来奇异值、数值秩与最小范数解等信息；正规方程法形成 $\boldsymbol{A}^{\mathsf{T}}\boldsymbol{A}$ 约需 md^2 次，再加 $\frac{1}{3}d^3$ 的 Cholesky。

稀疏分解的成本由填充决定，而填充又依赖非零元的排列顺序，不能直接套用稠密估计。

不计预条件的标准迭代实现，每步开销如表 14.2所示。短递推方法只需固定个数的工作向量，GMRES 则要保存全部基向量，第 k 步的正交化约需 $4kd$ 次运算，所以存储与正交化成本随步数增长；重启和再正交化的成本须另计。

方法	每步的矩阵作用	工作存储
CG、MINRES	一次 $\boldsymbol{A}$	固定个数的向量
GMRES	一次 $\boldsymbol{A}$，外加对已有基的正交化	随步数增长的基
BiCG	一次 $\boldsymbol{A}$ 与一次 $\boldsymbol{A}^{\mathsf{T}}$	固定个数的向量
BiCGSTAB	通常两次 $\boldsymbol{A}$	固定个数的向量
LSQR、LSMR	一次 $\boldsymbol{A}$ 与一次 $\boldsymbol{A}^{\mathsf{T}}$	固定个数的向量

表 14.2　Krylov 方法的每步开销（不计预条件）。

步数由各自的收敛机制决定。定常迭代看迭代矩阵的谱半径，接近 1 时需要很多轮。CG 使误差的 $\boldsymbol{A}$ 范数在 Krylov 子空间中最小，步数取决于 $\sqrt{\kappa_2(\boldsymbol{A})}$ 与特征值的分布，特征值聚成少数几簇时可以很少。GMRES 最小化残差，对非正规矩阵只看特征值不足以判断收敛，重启还可能使残差停滞。LSQR、LSMR 的收敛由 $\boldsymbol{A}$ 的奇异值分布决定，相当于对 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 用 CG。Kaczmarz 的收缩由各行法向之间的夹角和访问顺序决定，两行接近平行时交替投影走成锯齿。

所以比较应在同一问题、同一停止要求下按总成本进行，不能只以单步便宜、条件数较小或某次算例步数少，就宣布一种方法普遍更快。

14.3.4 数值稳定性

比较稳定性时，先区分三种误差来源：问题本身的病态，有限精度下的算法行为，以及迭代提前停止留下的误差。第一种与算法无关，由问题的条件数刻画。对满列秩长方矩阵，$\kappa_2(\boldsymbol{A}) = \sigma_{\max}(\boldsymbol{A})/\sigma_{\min}(\boldsymbol{A})$，正规方程的条件数是它的平方（式 (14.4)）；比较计算路线时，用第 14.1.2节的残差、前向误差与后向误差作标准。

LSQR、LSMR 不显式形成正规矩阵，改善的是计算路线，并不消除原问题的小奇异值或病态。

核验要按目标进行。相容方程检查原残差及按数据尺度化的容差；不相容最小二乘检查原残差与正规残差 $\boldsymbol{A}^{\top}\boldsymbol{r}$；需要最小范数解时，还要检查初值和零空间的处理，例如 Krylov 方法与 Kaczmarz 从零初值出发时，迭代量留在 $\operatorname{range}\boldsymbol{A}^{\top}$ 中。有限精度下，递推更新的残差可能逐渐偏离重新计算的 $\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}_k$，预条件后的残差范数也可能与原问题的不同，所以最后应回到原数据重新计算残差。

各种风险出现在不同的算法步骤上，处理办法也不同。直接分解的风险在主元：LU 与 $\mathrm{LDL}^{\top}$ 要监测增长因子，必要时改用正交分解。Krylov 递推的风险在基失去正交，可以再正交化，或接受损失并以真实残差核验。

BiCG、BiCGSTAB 以及用于非正定矩阵的 CG 可能遇到过小的递推分母，要区分已收敛与失效，再重启或改用 GMRES、MINRES。重启 GMRES 可能停滞，可以增大重启长度或改进预条件。标准 Kaczmarz 用于不相容系统时会在各行之间循环，应改用扩展 Kaczmarz 或 LSQR。这些偏差各有来源，不宜统称为“不稳定”。

预条件还要核对是否仍在解同一个问题（第 12.11节）。在相容方程上，左右预条件都不改变解。

对不相容最小二乘，左乘可逆矩阵 $\boldsymbol{M}^{-1}$ 以后最小化的是

$$(\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x})^{\top}(\boldsymbol{M}\boldsymbol{M}^{\top})^{-1}(\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}),$$

即以 $(\boldsymbol{M}\boldsymbol{M}^{\mathsf{T}})^{-1}$ 为权的加权最小二乘（第 9.5节），解一般不同于原问题。对秩亏问题，右换元 $\boldsymbol{x}=\boldsymbol{N}^{-1}\boldsymbol{y}$ 后在 $\boldsymbol{y}$ 中取最小范数，对应的是使 $\|\boldsymbol{N}\boldsymbol{x}\|_2$ 最小的 $\boldsymbol{x}$，一般不是原坐标中的最小范数解。所以比较预条件要结合第 9章的目标与选解准则，不能仅凭变换后更容易计算，就认定它仍解决同一个问题。

14.3.5 典型问题的方法选择

能保存并分解矩阵的中小型问题，或者有多个右端时，先比较直接分解的总成本：对称正定用 Cholesky，对称不定用分块 $\mathrm{LDL}^{\mathsf{T}}$，一般方阵用部分主元 LU，已有分解而矩阵只作低秩修改时用 Woodbury 更新。

大型稀疏方程按结构比较：对称正定用 CG，对称不定用 MINRES，一般非对称用 GMRES 或 BiCGSTAB，并配合可用的预条件。定常迭代（第 11章）作为独立求解器往往较慢，但准备成本低、更新是局部的、容易实现，常被用作 Krylov 方法的预条件或其他算法中的平滑步骤，价值不只在于单独求解。

大型稀疏、长方或不相容的最小二乘，用 LSQR 或 LSMR：它们只用 $\boldsymbol{A}\boldsymbol{v}$ 和 $\boldsymbol{A}^{\mathsf{T}}\boldsymbol{u}$，保留原始的矩形问题，并以有限的向量存储迭代。它们也能有效求解相容的线性方程，不能笼统断言在方阵上效率更低。

但当原方阵可以直接用 CG、MINRES 等结构化方法时，后者每步只需一次矩阵作用，收敛由 $\boldsymbol{A}$ 本身的谱决定；LSQR、LSMR 每步两次乘法，收敛由等效正规方程的谱决定，专用的方程方法通常更有优势。实际取舍还取决于预条件、矩阵访问的成本和目标精度。

只能逐行读取、观测按行到达或矩阵的行非常稀疏时，Kaczmarz 的单步成本最低，但全局收敛可能很慢，应按遍历全部数据的次数比较。标准 Kaczmarz 首先是相容方程的行投影方法，处理一般不相容最小二乘要用扩展版本，并计入列校正的附加成本，不能把“按行处理方便”等同于“适合所有最小二乘”。所有这些比较最终都回到第 9章确定的求解目标与选解准则，以及第 14.1节的误差要求。

14.4 本章小结

本章把一个求解结果的可信程度拆成三种来源分别处理。第一种是问题本身的敏感性：可逆方程的解在右端或系数矩阵受有限扰动时，相对误差不超过条件数乘相对扰动，再除以到奇异边界的余量 $1-\kappa(\boldsymbol{A})\rho_A$；误差沿小奇异值方向放大最多。

最小二乘中，拟合值与残差的变化受观测变化控制，系数却按 $1/\sigma_r$ 放大，拟合得好不等于系数可靠。伪逆只在正奇异值有共同下界时连续，秩增加处不连续，所以数值秩要按误差水平而不是按是否精确为零来确定。

第二种是算法在有限精度下引入的误差。残差小只说明后向误差小；前向误差约不超过条件数乘后向误差。后向稳定的算法也不能改善病态问题，但能避免额外损失：形成正规方程使条件数平方，而 QR、SVD 与 LSQR、LSMR 直接作用于 $\boldsymbol{A}$。第三种是迭代提前停止留下的误差，需要用真实残差和相应的正规残差核验，并分清达到容差与只是停止计算。

当问题本身太敏感时，可以主动改变目标。Tikhonov 正则化等价于增广最小二乘，解唯一当且仅当 $\ker \boldsymbol{A} \cap \ker \boldsymbol{\Gamma} = \{\mathbf{0}\}$；岭回归在奇异方向上把增益 $1/\sigma_i$ 换成有界的 $\sigma_i/(\sigma_i^2 + \lambda)$。谱截断只在保留的奇异方向上取倒数，是限制子空间中的最小二乘解，误差分成保留方向的噪声放大与舍弃方向的偏差两部分。两者都以拟合误差和偏差换取稳定，参数要联系噪声规模与任务确定；它们解的是新目标，较小的系数不能当作原问题解得更准。

选择方法时，先固定求解目标与验收标准：相容方程看原残差，不相容最小二乘还要看正规残差，最小范数还要排除零空间分量。再按矩阵形状、对称正定性、秩、稀疏性与数据访问方式确定可用的方法，以相同精度下的准备、单步、步数、存储与通信总成本比较，并分开问题病态、算法误差与提前停止三种误差。

没有一种方法在所有问题上都更好：直接分解适合能存储因子或多右端的问题，Krylov 方法适合大型稀疏问题，LSQR、LSMR 保留矩形最小二乘的结构，行投影法适合逐行访问的数据。

第 15 章

矩阵逼近

一组数据排成矩阵 $\boldsymbol{A}$，许多列大致落在少数几个方向上，能否只用 k 个方向重建全部列，使重建误差最小？一个测得的旋转矩阵因噪声不再正交，离它最近的正交矩阵又是哪一个？两个问题都是给定矩阵 $\boldsymbol{A}$，在秩或正交性的约束下寻找离它最近的矩阵。本章要回答：最小误差是多少，哪个矩阵取得它，它是否唯一，以及误差度量或约束改变时答案怎样变化。

与前几章不同，这里的未知量是矩阵本身。第 9—14章求解 $\boldsymbol{Ax} \approx \boldsymbol{b}$ 时，未知量是输入向量 $\boldsymbol{x}$；矩阵逼近没有右端 $\boldsymbol{b}$，要输出的是代替 $\boldsymbol{A}$ 的矩阵，残差 $\boldsymbol{A} - \boldsymbol{X}$ 也是矩阵。

第 15.1节写清约束与误差。秩约束下的解法分两步：先固定重建方向，最优系数由正交投影给出；再选择方向。第 15.2节在秩一情形完成这两步，选方向化为 Rayleigh 商的极值，并对一般实对称矩阵求出它的最大、最小值。第 15.3节把直线推广为 k 维子空间，选子空间化为迹极值，由此证明截断 SVD 在 Frobenius 范数与谱范数下都最优，并讨论唯一性。

随后两节分别改变度量与约束。第 15.4节用加权长度规定单位方向，得到广义 Rayleigh 商，并把可分离权重下的低秩逼近化归为普通情形。第 15.5节把约束换成正交性：目标变成关于未知矩阵线性的迹，最优解是极分解的正交因子；要求旋转时，再在最小奇异方向上作符号修正。第 15.6节说明怎样检验计算结果，区分约束带来的逼近误差与计算误差。

本章使用第 4章的对称矩阵谱分解与第 5章的奇异值分解。这两种分解的存在已在那里证明，不依赖本章的极值结论；本章只用它们读出极值与最优解。第 7章已经提前使用了本章的 Rayleigh–Ritz 定理与最佳低秩逼近定理，它们的证明只依赖这两种分解。

正交逼近依赖第 6章：那里构造了极分解的正交因子，本章证明它的最优性。加权部分用到第 3章的加权内积与 Gram 因子，计算时用到第 10章的 Cholesky 分解。截断 SVD 也出现在第 14章，但那里是为了稳定地求解方程，本章则把截断矩阵本身作为近似对象来评价。

15.1 矩阵逼近问题

数据矩阵常常近似低秩：许多列虽然各不相同，却大致落在少数几个方向张成的子空间里。存储和计算时，我们希望只保留这些方向，用一个秩较低的矩阵代替原矩阵，同时使重建误差尽量小。另一类情形是，某个矩阵按其含义应当正交，例如一次测量得到的旋转，但测量误差使它不再正交；这时要找一个正交矩阵来代替它，并且离测得的矩阵尽量近。

两类问题有共同的形式，称为**矩阵逼近**（matrix approximation）。已知矩阵 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$，规定一个允许的矩阵集合 $\mathcal{X}$ 与一种误差范数，求

$$\min_{\boldsymbol{X}\in\mathcal{X}} \|\boldsymbol{A}-\boldsymbol{X}\|,$$

以及取得最小值的 $\boldsymbol{X}$。$\mathcal{X}$ 可以是全部秩不超过 k 的矩阵，也可以是全部正交矩阵。

如章首所说，$\boldsymbol{A}$ 在这里不是方程的系数矩阵：没有右端 $\boldsymbol{b}$，也不求输入向量 $\boldsymbol{x}$，要输出的是近似矩阵 $\boldsymbol{X}$ 及最小误差。

先采用 Frobenius 误差。把 $\boldsymbol{A}=[\boldsymbol{a}_1,\dots,\boldsymbol{a}_d]$ 的列看成 d 个待重建的向量，近似矩阵 $\boldsymbol{X}=[\boldsymbol{x}_1,\dots,\boldsymbol{x}_d]$ 的列是它们的重建，则

$$\|\boldsymbol{A}-\boldsymbol{X}\|_{\mathrm{F}}^2=\sum_{j=1}^{d}\|\boldsymbol{a}_j-\boldsymbol{x}_j\|_2^2,$$

即各列平方偏差之和。约束 $\operatorname{rank}\boldsymbol{X}\le k$ 等价于 $\boldsymbol{X}$ 的列空间维数不超过 k，即全部重建向量共用至多 k 个独立方向。于是秩约束下的问题同时要选两样东西：保留哪些方向，以及每一列在这些方向上取什么系数。

谱范数误差 $\|\boldsymbol{A}-\boldsymbol{X}\|_2$ 只记录最坏的单位输入方向上的偏差，第 15.3.3节将比较两种范数下的结论。第 15.5节再把约束换成正交性：那时允许集合不再由秩预算描述，求解方法也随之改变。

取 $0\le k\le \min(m,d)$，并记 $r=\operatorname{rank}\boldsymbol{A}$。两种边界情形可以直接回答：$k=0$ 时只能取 $\boldsymbol{X}=\boldsymbol{0}$，误差为 $\|\boldsymbol{A}\|_{\mathrm{F}}^2$；$k\ge r$ 时可以取 $\boldsymbol{X}=\boldsymbol{A}$，误差为零，而误差为零又迫使 $\boldsymbol{X}=\boldsymbol{A}$。真正需要研究的是 $1\le k<r$。

示例 15.1　三个坐标向量的重建　取 $\boldsymbol{A}=[3\boldsymbol{e}_1,2\boldsymbol{e}_2,\boldsymbol{e}_3]$，即 $\boldsymbol{A}=\operatorname{diag}(3,2,1)$，三列的长度平方为 $9,4,1$，总和 $\|\boldsymbol{A}\|_{\mathrm{F}}^2=14$。取 $k=2$，问题就是用一个过原点的平面重建这三列。把每一列投影到平面上，称投影长度平方之和为保留量，总和中剩下的部分为损失。先比较三个坐标平面：

- $\operatorname{span}\{\boldsymbol{e}_1,\boldsymbol{e}_2\}$：保留 $9+4=13$，损失 1；

- $\operatorname{span}\{\boldsymbol{e}_1, \boldsymbol{e}_3\}$：保留 $9+1=10$，损失 4；
- $\operatorname{span}\{\boldsymbol{e}_2, \boldsymbol{e}_3\}$：保留 $4+1=5$，损失 9。

保留最长的两列损失最小。不过这只是三个候选之间的比较：倾斜的平面会同时部分保留三列，它能否比 $\operatorname{span}\{\boldsymbol{e}_1, \boldsymbol{e}_2\}$ 更好，此时还不知道；在平面内取投影是否就是最好的重建，也还需要证明。

示例留下的两个问题，即方向给定时怎样取系数、怎样选方向，下面先在 $k=1$ 时回答（第 15.2节），再推广到一般的 k（第 15.3节）。

15.2 秩一逼近

$k=1$ 时，全部列都用同一个方向的倍数来重建。我们先固定这个方向，求每一列的最优系数；再在全部方向中选出保留平方长度最多的一个。第二步将化成单位向量上的二次型极值问题，它的解由谱分解给出。

15.2.1 固定方向下的最优系数

先写出全部候选。若 $\boldsymbol{X} \neq \boldsymbol{0}$ 且 $\operatorname{rank} \boldsymbol{X} \leq 1$，则 $\boldsymbol{X}$ 的列空间是一条直线，由某个非零向量 $\boldsymbol{a}$ 张成，每一列都是 $\boldsymbol{a}$ 的倍数：$\boldsymbol{x}_j = b_j \boldsymbol{a}$，即 $\boldsymbol{X} = \boldsymbol{a}\boldsymbol{b}^{\top}$。令 $\boldsymbol{u} = \boldsymbol{a}/\|\boldsymbol{a}\|_2$、$\boldsymbol{c} = \|\boldsymbol{a}\|_2 \boldsymbol{b}$，就有 $\boldsymbol{X} = \boldsymbol{u}\boldsymbol{c}^{\top}$ 且 $\|\boldsymbol{u}\|_2 = 1$。方向的长度可以全部吸收到系数 $\boldsymbol{c}$ 中，所以要求 $\boldsymbol{u}$ 为单位向量不会丢失任何非零候选；$\boldsymbol{X} = \boldsymbol{0}$ 则对应 $\boldsymbol{c} = \boldsymbol{0}$。于是秩不超过一的矩阵恰好是全部 $\boldsymbol{u}\boldsymbol{c}^{\top}$，其中 $\|\boldsymbol{u}\|_2 = 1$，$\boldsymbol{c} \in \mathbb{R}^d$。

固定单位方向 $\boldsymbol{u}$，第 j 列的重建是 $c_j \boldsymbol{u}$。展开平方误差并配方，利用 $\boldsymbol{u}^{\top}\boldsymbol{u} = 1$，

$$\|\boldsymbol{a}_j - c_j \boldsymbol{u}\|_2^2 = \|\boldsymbol{a}_j\|_2^2 - 2c_j \boldsymbol{u}^{\top}\boldsymbol{a}_j + c_j^2 = \|\boldsymbol{a}_j\|_2^2 - (\boldsymbol{u}^{\top}\boldsymbol{a}_j)^2 + (c_j - \boldsymbol{u}^{\top}\boldsymbol{a}_j)^2.$$

只有最后一项依赖 c_j，且它非负，所以 $c_j = \boldsymbol{u}^{\top}\boldsymbol{a}_j$ 是唯一的最优系数，也就是 $\boldsymbol{a}_j$ 在 $\boldsymbol{u}$ 上的正交投影系数。每一列的系数只与该列有关，可以逐列独立求出。合起来写，$\boldsymbol{c} = \boldsymbol{A}^{\top}\boldsymbol{u}$，最优重建是 $\boldsymbol{u}\boldsymbol{u}^{\top}\boldsymbol{A}$，其中 $\boldsymbol{u}\boldsymbol{u}^{\top}$ 是到直线 $\operatorname{span}\{\boldsymbol{u}\}$ 的正交投影。

把最优系数代回并对 j 求和，

$$\begin{aligned} \|\boldsymbol{A} - \boldsymbol{u}\boldsymbol{u}^{\top}\boldsymbol{A}\|_{\mathrm{F}}^2 &= \|\boldsymbol{A}\|_{\mathrm{F}}^2 - \sum_{j=1}^{d} (\boldsymbol{u}^{\top}\boldsymbol{a}_j)^2 \\ &= \|\boldsymbol{A}\|_{\mathrm{F}}^2 - \boldsymbol{u}^{\top}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{u}. \end{aligned}$$

称 $\boldsymbol{u}^{\top}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{u}$ 为方向 $\boldsymbol{u}$ 的保留量，它是各列在 $\boldsymbol{u}$ 上投影长度的平方和。总平方长度固定，误差最小等价于保留量最大。于是秩一逼近分成两步：给

定方向后，每列做一次内积求出投影系数；再寻找保留量最大的单位方向。后一步由下一小节解决。

示例 15.2 固定方向时的秩一重建 取

$$\boldsymbol{A}=\begin{bmatrix}2&1\\1&2\end{bmatrix},\qquad \boldsymbol{u}=\frac{1}{\sqrt{2}}\begin{bmatrix}1\\1\end{bmatrix}.$$

方向固定后，每列的系数就是它在 $\boldsymbol{u}$ 上的投影长度。逐列计算，$c_1=\boldsymbol{u}^{\top}\boldsymbol{a}_1=(2+1)/\sqrt{2}=3/\sqrt{2}$，$c_2=\boldsymbol{u}^{\top}\boldsymbol{a}_2=(1+2)/\sqrt{2}=3/\sqrt{2}$。重建矩阵为

$$\boldsymbol{u}\boldsymbol{c}^{\top}=\frac{1}{\sqrt{2}}\cdot\frac{3}{\sqrt{2}}\begin{bmatrix}1&1\\1&1\end{bmatrix}=\frac{3}{2}\begin{bmatrix}1&1\\1&1\end{bmatrix},\qquad \boldsymbol{A}-\boldsymbol{u}\boldsymbol{c}^{\top}=\frac{1}{2}\begin{bmatrix}1&-1\\-1&1\end{bmatrix}.$$

残差四个元素都是 $\pm1/2$，平方和为 1。也可以不形成残差，用上面的公式核对：$\|\boldsymbol{A}\|_{\mathrm{F}}^2=4+1+1+4=10$，保留量 $c_1^2+c_2^2=9$，误差 $10-9=1$。这个方向是否最好，还要与其他方向比较。

15.2.2 Rayleigh 商与最优方向

上一小节把选方向化成：在单位向量中最大化 $\boldsymbol{u}^{\top}\boldsymbol{G}\boldsymbol{u}$，其中 $\boldsymbol{G}=\boldsymbol{A}\boldsymbol{A}^{\top}$ 对称半正定。同样的问题对一般的实对称矩阵 $\boldsymbol{S}$ 也会出现：第 9.6节的齐次最小二乘要在单位向量中求二次型的最小值，第 7章比较扰动前后的特征值时也要用到这类极值。所以下面先对任意实对称 $\boldsymbol{S}$ 回答：输入方向改变时，二次型 $\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}$ 最大、最小能取到多少，在哪些方向取到？然后再回到 $\boldsymbol{G}$。

先看最简单的对角矩阵 $\boldsymbol{S}=\operatorname{diag}(4,1)$，此时 $\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}=4x_1^2+x_2^2$。固定 $\boldsymbol{x}^{\top}\boldsymbol{x}=1$，比较不同单位方向上的值：第一坐标方向 $\boldsymbol{e}_1$ 给出 4，第二坐标方向 $\boldsymbol{e}_2$ 给出 1。看起来最大值是 4、最小值是 1，但这只比较了两个候选。单位圆上还有无穷多个倾斜方向，例如 $(1,1)^{\top}/\sqrt{2}$ 给出 $5/2$；要证明全局极值，必须对所有单位方向都作出比较。

长度约束的作用是让比较只关注方向。二次型随 $\boldsymbol{x}$ 的长度按平方增长：若不加约束，把 $\boldsymbol{e}_2$ 放大到 $3\boldsymbol{e}_2$，二次型就变成 9，超过了 $\boldsymbol{e}_1$ 方向的值，这只反映了输入被放大，与方向无关。把长度除掉，就得到只依赖方向的量，称为Rayleigh 商（Rayleigh quotient）。

定义 15.3 Rayleigh 商 对实对称矩阵 $\boldsymbol{S}\in\mathbb{R}^{d\times d}$ 与 $\boldsymbol{x}\neq\boldsymbol{0}$，

$$R_{\boldsymbol{S}}(\boldsymbol{x})=\frac{\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}}{\boldsymbol{x}^{\top}\boldsymbol{x}}. \tag{15.1}$$

把 $\boldsymbol{x}$ 换成 $c\boldsymbol{x}$（$c \neq 0$）时分子分母同乘 c^2，Rayleigh 商不变，所以它只依赖 $\boldsymbol{x}$ 所在的直线。对任意 $\boldsymbol{x} \neq \boldsymbol{0}$，$R_{\boldsymbol{S}}(\boldsymbol{x})$ 等于单位向量 $\boldsymbol{x}/\|\boldsymbol{x}\|_2$ 上的二次型值；反过来，单位向量上的二次型值就是它的 Rayleigh 商。因此求 Rayleigh 商在全部非零向量上的极值，等价于在单位球面上求二次型的极值。

谱分解把这种比较化为对特征值的比较。按第 4.3.1节的约定，把 $\boldsymbol{S}$ 的特征值排成 $\lambda_1 \geq \cdots \geq \lambda_d$，对应标准正交特征向量 $\boldsymbol{q}_1, \dots, \boldsymbol{q}_d$。对单位向量 $\boldsymbol{x} = \sum_i c_i \boldsymbol{q}_i$，有 $\sum_i c_i^2 = \|\boldsymbol{x}\|_2^2 = 1$，由二次型展开式 (4.5)，

$$R_{\boldsymbol{S}}(\boldsymbol{x}) = \sum_{i=1}^{d} \lambda_i c_i^2 .$$

它是各特征值以 c_i^2 为权的加权平均：权重非负，总和为 1。加权平均介于被平均各数的最小值与最大值之间，由此得到两端特征值的极值刻画。

定理 15.4　Rayleigh–Ritz　设 $\boldsymbol{S} \in \mathbb{R}^{d\times d}$ 对称，特征值为 $\lambda_1 \geq \cdots \geq \lambda_d$，对应标准正交特征向量 $\boldsymbol{q}_1, \dots, \boldsymbol{q}_d$。则对一切 $\boldsymbol{x} \neq \boldsymbol{0}$，

$$\lambda_d \leq R_{\boldsymbol{S}}(\boldsymbol{x}) \leq \lambda_1, \tag{15.2}$$

于是 $\max_{\boldsymbol{x}\neq\boldsymbol{0}} R_{\boldsymbol{S}}(\boldsymbol{x}) = \lambda_1$，$\min_{\boldsymbol{x}\neq\boldsymbol{0}} R_{\boldsymbol{S}}(\boldsymbol{x}) = \lambda_d$，分别在 $\boldsymbol{q}_1$ 与 $\boldsymbol{q}_d$ 取到。进一步，$R_{\boldsymbol{S}}(\boldsymbol{x}) = \lambda_1$ 当且仅当 $\boldsymbol{x}$ 是 $\ker(\boldsymbol{S} - \lambda_1 \boldsymbol{I})$ 中的非零向量；$R_{\boldsymbol{S}}(\boldsymbol{x}) = \lambda_d$ 当且仅当 $\boldsymbol{x}$ 是 $\ker(\boldsymbol{S} - \lambda_d \boldsymbol{I})$ 中的非零向量。

证明　Rayleigh 商不随缩放改变，只需对单位向量 $\boldsymbol{x} = \sum_i c_i \boldsymbol{q}_i$ 证明。这时 $R_{\boldsymbol{S}}(\boldsymbol{x}) = \sum_i \lambda_i c_i^2$ 且 $\sum_i c_i^2 = 1$，所以

$$\lambda_1 - R_{\boldsymbol{S}}(\boldsymbol{x}) = \sum_{i=1}^{d} (\lambda_1 - \lambda_i) c_i^2 \geq 0,$$

每一项都非负。同理 $R_{\boldsymbol{S}}(\boldsymbol{x}) - \lambda_d = \sum_i (\lambda_i - \lambda_d) c_i^2 \geq 0$。这就是式 (15.2)。取 $\boldsymbol{x} = \boldsymbol{q}_1$ 时 $c_1 = 1$、其余 $c_i = 0$，得 $R_{\boldsymbol{S}}(\boldsymbol{q}_1) = \lambda_1$；取 $\boldsymbol{x} = \boldsymbol{q}_d$ 得 λ_d。所以两端的界都能取到。

再看取等条件。上面的和式等于零，当且仅当每一项都为零，即凡 $\lambda_i < \lambda_1$ 的 i 都有 $c_i = 0$。这恰好说明 $\boldsymbol{x}$ 落在满足 $\lambda_i = \lambda_1$ 的那些 $\boldsymbol{q}_i$ 的张成中；由定理 4.23，这个张成就是特征空间 $\ker(\boldsymbol{S} - \lambda_1 \boldsymbol{I})$。最小值的情形相同。 ■

图 15.1用一个二阶对称矩阵画出这一关系：二次型的水平椭圆在特征方向处与单位圆相切，切点处取到极值。

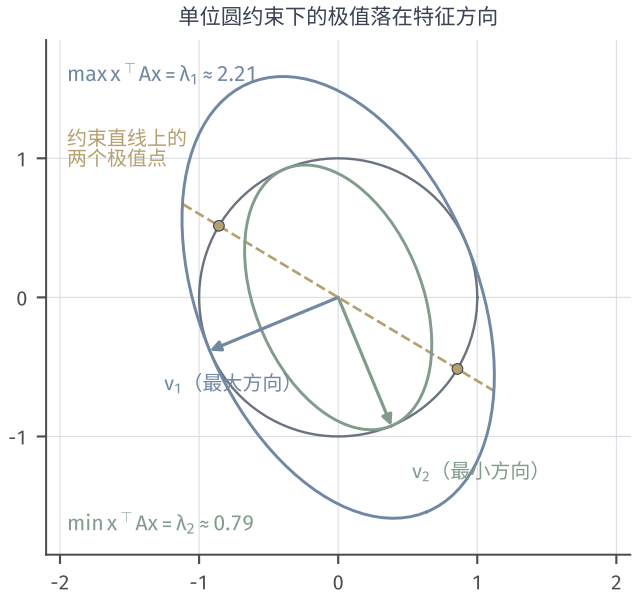


图 15.1 单位圆约束下的极值落在特征方向。$\boldsymbol{S} = \left[\begin{smallmatrix} 2 & 0.5 \\ 0.5 & 1 \end{smallmatrix}\right]$，灰圆为 $\|\boldsymbol{x}\| = 1$。蓝椭圆 $\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x} = \lambda_1 \approx 2.21$ 在 $\pm\boldsymbol{v}_1$ 处与单位圆相切（最大值），绿椭圆 $= \lambda_2 \approx 0.79$ 在 $\pm\boldsymbol{v}_2$ 处相切（最小值）；黄色虚线为子空间约束直线，其上黄点是该约束下的两个极值，第 7.2.1节的最小最大原理使用这种限制。$\lambda_{1,2} = (3 \pm \sqrt{2})/2$。固定复算。

回到开头的对角矩阵，现在可以完成全部单位方向的比较。

示例 15.5 对角矩阵在全部单位方向上的比较 取 $\boldsymbol{S} = \mathrm{diag}(4, 1)$。每个单位向量都能写成 $\boldsymbol{x} = (\cos\theta, \sin\theta)^{\top}$，其中 $\theta \in [0, 2\pi)$，于是

$$\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x} = 4\cos^2\theta + \sin^2\theta = 1 + 3\cos^2\theta.$$

由 $0 \le \cos^2\theta \le 1$，它介于 1 与 4 之间：$\cos^2\theta = 1$ 即 $\boldsymbol{x} = \pm\boldsymbol{e}_1$ 时取最大值 4，$\cos^2\theta = 0$ 即 $\boldsymbol{x} = \pm\boldsymbol{e}_2$ 时取最小值 1。

可见最大值 4 与最小值 1 正是两个特征值，取到它们的方向正是特征方向，与定理 15.4一致；倾斜方向的值都严格介于两者之间。

定理不要求 $\boldsymbol{S}$ 半正定。二次型可以取负值，例如 $\boldsymbol{S} = \mathrm{diag}(1, -2)$ 时 $\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x} = x_1^2 - 2x_2^2$，单位方向上的值仍介于 -2 与 1 之间，两端分别在 $\pm\boldsymbol{e}_2$ 与 $\pm\boldsymbol{e}_1$ 取到。

还要区分最优值与最优方向的唯一性。最大值 λ_1 总是唯一的数，取到它的方向则由特征空间 $\ker(\boldsymbol{S} - \lambda_1\boldsymbol{I})$ 决定。λ_1 单重时，这个空间是一条直线，单位最优方向只有 $\pm\boldsymbol{q}_1$ 两个，相差一个符号；λ_1 重复时，空间中每个单位向量都给出最大值，例如 $\boldsymbol{S} = \boldsymbol{I}$ 时所有单位方向都是最优的。

重根时，谱分解中的 $\boldsymbol{q}_1$ 只是最优方向中的一个代表，取决于特征基的选择；最优方向组成的集合则由定理 4.23唯一确定。最小值的情形相同。

一个常见的特例是 $\boldsymbol{S} = \boldsymbol{A}^{\top}\boldsymbol{A}$，其中 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$。这时

$$R_{\boldsymbol{A}^{\top}\boldsymbol{A}}(\boldsymbol{x}) = \frac{\boldsymbol{x}^{\top}\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{x}}{\boldsymbol{x}^{\top}\boldsymbol{x}} = \frac{\|\boldsymbol{A}\boldsymbol{x}\|_2^2}{\|\boldsymbol{x}\|_2^2},$$

即输出长度与输入长度之比的平方。第 5章已经说明 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 的特征值是奇异值的平方（$d > m$ 时补上零），所以定理 15.4给出那里最大、最小输出长度的另一种解释：单位输入的输出长度最大为 σ_1，在 $\boldsymbol{v}_1$ 取到；最小为 $\sqrt{\lambda_d}$，其中 λ_d 是 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 的最小特征值，在它的特征方向取到。

第 9.6节的齐次最小二乘正是在单位输入中最小化这一量。若 $\boldsymbol{A}$ 有非零的零空间，最小值为零，任一单位零空间向量都最优；若 $\boldsymbol{A}$ 满列秩，则 $\boldsymbol{A}\boldsymbol{x} \neq \boldsymbol{0}$ 对一切 $\boldsymbol{x} \neq \boldsymbol{0}$ 成立，$\boldsymbol{A}^{\top}\boldsymbol{A} \succ 0$，由定理 4.25，最小值为正。

现在回到秩一逼近，取 $\boldsymbol{S} = \boldsymbol{G} = \boldsymbol{A}\boldsymbol{A}^{\top}$。由定理 15.4，单位方向的保留量 $\boldsymbol{u}^{\top}\boldsymbol{G}\boldsymbol{u}$ 最大为 $\lambda_1(\boldsymbol{G})$，恰在 $\ker(\boldsymbol{G} - \lambda_1(\boldsymbol{G})\boldsymbol{I})$ 中的单位向量处取到，最小平方误差为 $\|\boldsymbol{A}\|_{\mathrm{F}}^2 - \lambda_1(\boldsymbol{G})$。这里只使用了第 4章已经证明的谱分解；谱分解的存在不依赖本节的极值结论，本节只是用它读出极值。

示例 15.6　比较两个特征方向　沿用示例 15.2的 $\boldsymbol{A}$，

$$\boldsymbol{G} = \boldsymbol{A}\boldsymbol{A}^{\top} = \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix}.$$

$\boldsymbol{G}(1,1)^{\top} = 9(1,1)^{\top}$，$\boldsymbol{G}(1,-1)^{\top} = (1,-1)^{\top}$，所以两个标准正交特征方向 $(1,1)^{\top}/\sqrt{2}$ 与 $(1,-1)^{\top}/\sqrt{2}$ 的保留量分别是 9 与 1。前者给出重建平方误差 $10 - 9 = 1$，后者给出 $10 - 1 = 9$。由定理 15.4，任何单位方向的误差都介于 1 与 9 之间，所以示例 15.2所取的方向已是最优方向，而 $(1,-1)^{\top}/\sqrt{2}$ 是最差的方向。

15.2.3 最优解与逼近误差

上一小节用 $\boldsymbol{G}$ 的特征方向给出了最优直线，现在把它与 $\boldsymbol{A}$ 的奇异值分解联系起来，写出最优近似矩阵。设 $\boldsymbol{A} \neq \boldsymbol{0}$，奇异值为 $\sigma_1 \geq \cdots \geq \sigma_r > 0$。式 (5.3)说明，$\boldsymbol{G} = \boldsymbol{A}\boldsymbol{A}^{\top}$ 的特征值是 $\sigma_1^2, \ldots, \sigma_r^2$ 及 $m - r$ 个零，左奇异向量 $\boldsymbol{u}_i$ 是对应的特征向量。因此最大保留量为 $\lambda_1(\boldsymbol{G}) = \sigma_1^2$，取 $\boldsymbol{u} = \boldsymbol{u}_1$ 即可达到，最小平方误差为 $\|\boldsymbol{A}\|_{\mathrm{F}}^2 - \sigma_1^2 = \sum_{i=2}^{r}\sigma_i^2$。

再由 $\boldsymbol{A}^{\top}\boldsymbol{u}_1 = \sigma_1\boldsymbol{v}_1$，最优系数是 $\boldsymbol{c} = \boldsymbol{A}^{\top}\boldsymbol{u}_1 = \sigma_1\boldsymbol{v}_1$，“最佳方向加最优系数”合成

$$\boldsymbol{A}_1 = \boldsymbol{u}_1\boldsymbol{u}_1^{\top}\boldsymbol{A} = \boldsymbol{u}_1(\boldsymbol{A}^{\top}\boldsymbol{u}_1)^{\top} = \sigma_1\boldsymbol{u}_1\boldsymbol{v}_1^{\top}.$$

这是原矩阵 $\boldsymbol{A}$ 的秩一近似，即和式 (5.1)的第一项，而不是 Gram 矩阵 $\boldsymbol{G}$ 的秩一近似。计算的输入是 $\boldsymbol{A}$ 及其已经求出的 SVD，输出是近似矩阵 $\boldsymbol{A}_1$；它不是某个方程的系数向量。

具体计算依次是：读取最大奇异值 σ_1 及配对的方向 $\boldsymbol{u}_1$、$\boldsymbol{v}_1$，作外积 $\boldsymbol{u}_1\boldsymbol{v}_1^{\top}$ 并乘以 σ_1，最后求残差 $\boldsymbol{A}-\boldsymbol{A}_1$ 并核对误差。沿用示例 15.2，$\boldsymbol{A}$ 对称正定，$\boldsymbol{A}(1,1)^{\top}=3(1,1)^{\top}$，$\boldsymbol{A}(1,-1)^{\top}=(1,-1)^{\top}$，所以 $\sigma_1=3$、$\sigma_2=1$，可取 $\boldsymbol{u}_1=\boldsymbol{v}_1=(1,1)^{\top}/\sqrt{2}$。于是

$$\boldsymbol{A}_1 = 3\cdot\frac{1}{2}\begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix} = \frac{3}{2}\begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix},$$

四个元素都是 $3/2$，两列成比例，秩为一；残差与示例 15.2相同，Frobenius 范数为 $1=\sigma_2$。在示例 15.1中，$\boldsymbol{G}=\operatorname{diag}(9,4,1)$，最佳直线是 $\boldsymbol{e}_1$ 方向，保留量 9，损失 5；重建 $3\boldsymbol{e}_1\boldsymbol{e}_1^{\top}$ 只保留第一列，另两列被投影成零。

这里用的是 $\boldsymbol{A}\boldsymbol{A}^{\top}$ 而不是 $\boldsymbol{A}^{\top}\boldsymbol{A}$，因为我们重建的是 $\mathbb{R}^m$ 中的列向量，保留量直接等于列向量在 $\boldsymbol{u}$ 上的投影长度平方之和，对应的是左奇异方向。若改为重建行向量，同样的推导会用到 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 与右奇异方向 $\boldsymbol{v}_1$，得到的近似 $\boldsymbol{A}\boldsymbol{v}_1\boldsymbol{v}_1^{\top}=\sigma_1\boldsymbol{u}_1\boldsymbol{v}_1^{\top}$ 是同一个矩阵。

这种解释依赖 $\boldsymbol{G}$ 是 Gram 矩阵。对一般不定的对称矩阵 $\boldsymbol{S}$，二次型值可能为负，不能把任意 Rayleigh 商的极值都解释成某个矩阵的最佳秩一逼近。

最后区分最优近似矩阵与它的表示。$\boldsymbol{A}=\boldsymbol{0}$ 时 $r=0$，每个方向的保留量都是零，唯一的最优近似是零矩阵。$\sigma_1>\sigma_2$（或 $r=1$）时，$\boldsymbol{G}$ 最大特征值的特征空间是一条直线，最优方向只有 $\pm\boldsymbol{u}_1$；把 $(\boldsymbol{u}_1,\boldsymbol{v}_1)$ 同时换成 $(-\boldsymbol{u}_1,-\boldsymbol{v}_1)$ 不改变外积，所以最优矩阵 $\boldsymbol{A}_1$ 唯一，不唯一的只是它的写法。

$\sigma_1=\sigma_2$ 时情况不同：最大特征值的特征空间至少二维，其中每个单位向量 $\boldsymbol{u}$ 都给出最优近似 $\boldsymbol{u}\boldsymbol{u}^{\top}\boldsymbol{A}$，不同的直线给出不同的矩阵。例如 $\boldsymbol{A}=\boldsymbol{I}_2$ 时，$\boldsymbol{e}_1\boldsymbol{e}_1^{\top}$ 与 $\boldsymbol{e}_2\boldsymbol{e}_2^{\top}$ 的平方误差都是 1。所以表示的非唯一性不等于近似矩阵的非唯一性，后者只来自最大奇异值重复。下一步保持误差标准不变，把允许保留的方向数由一个增加到 k 个。

15.3　秩 k 逼近

把共同的重建方向由一条直线扩展为 k 维子空间。与秩一情形一样，先固定子空间求系数，再选择子空间本身；用子空间的标准正交基，保留量写成一个迹，选子空间就成为迹的极值问题。由奇异值分解可以写出这个问题的解，即截断 SVD；随后在 Frobenius 范数与谱范数下证明它的最优性，并讨论最优解何时唯一。

15.3.1 子空间选择与迹极值

先固定一个 k 维子空间，问最好的重建是什么。以列标准正交的 $\boldsymbol{Y}\in\mathbb{R}^{m\times k}$ 表示这个子空间，$\boldsymbol{Y}^{\top}\boldsymbol{Y}=\boldsymbol{I}_k$；这里不用字母 $\boldsymbol{V}$，以免与右奇异向量矩阵混淆。列都落在 $\mathrm{range}(\boldsymbol{Y})$ 中的矩阵恰好是 $\boldsymbol{X}=\boldsymbol{Y}\boldsymbol{C}$，$\boldsymbol{C}\in\mathbb{R}^{k\times d}$ 的第 j 列是 $\boldsymbol{x}_j$ 在这组基下的系数。由第 3章的投影矩阵，$\boldsymbol{Y}\boldsymbol{Y}^{\top}$ 是到 $\mathrm{range}(\boldsymbol{Y})$ 的正交投影。

引理 15.7　固定子空间时的正交误差分解　设 $\boldsymbol{Y}\in\mathbb{R}^{m\times k}$ 满足 $\boldsymbol{Y}^{\top}\boldsymbol{Y}=\boldsymbol{I}_k$，则对任意 $\boldsymbol{C}\in\mathbb{R}^{k\times d}$，

$$\begin{aligned}\|\boldsymbol{A}-\boldsymbol{Y}\boldsymbol{C}\|_{\mathrm{F}}^{2}=\|(\boldsymbol{I}-\boldsymbol{Y}\boldsymbol{Y}^{\top})\boldsymbol{A}\|_{\mathrm{F}}^{2}\\+\|\boldsymbol{Y}^{\top}\boldsymbol{A}-\boldsymbol{C}\|_{\mathrm{F}}^{2},\end{aligned}\tag{15.3}$$

并且

$$\|(\boldsymbol{I}-\boldsymbol{Y}\boldsymbol{Y}^{\top})\boldsymbol{A}\|_{\mathrm{F}}^{2}=\|\boldsymbol{A}\|_{\mathrm{F}}^{2}-\mathrm{tr}(\boldsymbol{Y}^{\top}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{Y}).$$

因此固定子空间时，最优系数唯一，为 $\boldsymbol{C}=\boldsymbol{Y}^{\top}\boldsymbol{A}$，最优重建是正交投影 $\boldsymbol{Y}\boldsymbol{Y}^{\top}\boldsymbol{A}$。

证明　写 $\boldsymbol{A}-\boldsymbol{Y}\boldsymbol{C}=(\boldsymbol{I}-\boldsymbol{Y}\boldsymbol{Y}^{\top})\boldsymbol{A}+\boldsymbol{Y}(\boldsymbol{Y}^{\top}\boldsymbol{A}-\boldsymbol{C})$。逐列看，第 j 列是 $\boldsymbol{r}_j=(\boldsymbol{I}-\boldsymbol{Y}\boldsymbol{Y}^{\top})\boldsymbol{a}_j$ 与 $\boldsymbol{Y}\boldsymbol{z}_j$ 之和，其中 $\boldsymbol{z}_j$ 是 $\boldsymbol{Y}^{\top}\boldsymbol{A}-\boldsymbol{C}$ 的第 j 列。二者正交：

$$\boldsymbol{r}_j^{\top}\boldsymbol{Y}\boldsymbol{z}_j=\boldsymbol{a}_j^{\top}(\boldsymbol{I}-\boldsymbol{Y}\boldsymbol{Y}^{\top})\boldsymbol{Y}\boldsymbol{z}_j=\boldsymbol{a}_j^{\top}(\boldsymbol{Y}-\boldsymbol{Y}\boldsymbol{Y}^{\top}\boldsymbol{Y})\boldsymbol{z}_j=0,$$

这里用到 $\boldsymbol{Y}^{\top}\boldsymbol{Y}=\boldsymbol{I}_k$。又 $\|\boldsymbol{Y}\boldsymbol{z}_j\|_2^2=\boldsymbol{z}_j^{\top}\boldsymbol{Y}^{\top}\boldsymbol{Y}\boldsymbol{z}_j=\|\boldsymbol{z}_j\|_2^2$。由勾股定理，第 j 列的平方长度是 $\|\boldsymbol{r}_j\|_2^2+\|\boldsymbol{z}_j\|_2^2$；对 j 求和即得式 (15.3)。

对第二式，同样把 $\boldsymbol{a}_j$ 分解为 $\boldsymbol{Y}\boldsymbol{Y}^{\top}\boldsymbol{a}_j$ 与 $\boldsymbol{r}_j$ 两个正交部分，得 $\|\boldsymbol{r}_j\|_2^2=\|\boldsymbol{a}_j\|_2^2-\|\boldsymbol{Y}^{\top}\boldsymbol{a}_j\|_2^2$。求和后，

$$\sum_j\|\boldsymbol{Y}^{\top}\boldsymbol{a}_j\|_2^2=\|\boldsymbol{Y}^{\top}\boldsymbol{A}\|_{\mathrm{F}}^{2}=\mathrm{tr}(\boldsymbol{Y}^{\top}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{Y}).$$

最后，式 (15.3)右端第一项与 $\boldsymbol{C}$ 无关，第二项非负，且当且仅当 $\boldsymbol{C}=\boldsymbol{Y}^{\top}\boldsymbol{A}$ 时为零。 ∎

于是在固定子空间中，误差等于总平方长度减去保留量 $\mathrm{tr}(\boldsymbol{Y}^{\top}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{Y})$；$k=1$、$\boldsymbol{Y}=\boldsymbol{u}$ 时，这正是第 15.2.1节逐列配方得到的公式。示例 15.1中“先投影再计损失”的做法，也正是这个最优重建。共同子空间把 d 个向量各自的最小二乘问题合成了一个矩阵近似问题：子空间共用，系数逐列由投影给出。

这一化归覆盖全部候选矩阵，而不只覆盖事先写成投影形式的矩阵。设 $\operatorname{rank}\boldsymbol{X} = s \le k$。取 $\boldsymbol{X}$ 列空间的一组标准正交基，再在 $\mathbb{R}^m$ 中补充 $k-s$ 个与之正交的单位向量（$k \le m$，所以可以补齐），排成 $\boldsymbol{Y}$。则 $\boldsymbol{X}$ 的列都落在 $\operatorname{range}(\boldsymbol{Y})$ 中，$\boldsymbol{X} = \boldsymbol{Y}\boldsymbol{C}$，其中 $\boldsymbol{C} = \boldsymbol{Y}^{\top}\boldsymbol{X}$。由引理 15.7，

$$\|\boldsymbol{A} - \boldsymbol{X}\|_{\mathrm{F}}^2 \ge \|\boldsymbol{A}\|_{\mathrm{F}}^2 - \operatorname{tr}(\boldsymbol{Y}^{\top}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{Y}).$$

反过来，每个列标准正交的 $\boldsymbol{Y}$ 都给出秩不超过 k 的候选 $\boldsymbol{Y}\boldsymbol{Y}^{\top}\boldsymbol{A}$，误差恰为右端。两方面合起来，

$$\begin{aligned}\min_{\operatorname{rank}\boldsymbol{X}\le k} \|\boldsymbol{A} - \boldsymbol{X}\|_{\mathrm{F}}^2 \\ = \|\boldsymbol{A}\|_{\mathrm{F}}^2 - \max_{\boldsymbol{Y}^{\top}\boldsymbol{Y} = \boldsymbol{I}_k} \operatorname{tr}(\boldsymbol{Y}^{\top}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{Y}),\end{aligned} \tag{15.4}$$

只要右端的最大值存在；最大值的存在与取值由下面的定理 15.8给出。到这里，“同时选择方向与系数”化成了“选择子空间”。

再看保留量本身。对 $\boldsymbol{Y} = [\boldsymbol{y}_1, \dots, \boldsymbol{y}_k]$ 按列展开：

$$\operatorname{tr}(\boldsymbol{Y}^{\top}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{Y}) = \sum_{l=1}^{k} \boldsymbol{y}_l^{\top}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{y}_l = \sum_{l=1}^{k}\sum_{j=1}^{d} (\boldsymbol{y}_l^{\top}\boldsymbol{a}_j)^2.$$

迹把 k 个互相垂直方向上的保留量相加，$k = 1$ 时恰好回到上一节的 Rayleigh 商。它只依赖子空间，不依赖基的选取：把 $\boldsymbol{Y}$ 换成 $\boldsymbol{Y}\boldsymbol{O}$（$\boldsymbol{O}$ 为 k 阶正交矩阵）时，由迹的循环性，$\operatorname{tr}(\boldsymbol{O}^{\top}\boldsymbol{Y}^{\top}\boldsymbol{G}\boldsymbol{Y}\boldsymbol{O}) = \operatorname{tr}(\boldsymbol{Y}^{\top}\boldsymbol{G}\boldsymbol{Y})$，其中 $\boldsymbol{G} = \boldsymbol{A}\boldsymbol{A}^{\top}$。

据此，由式 (15.4)，秩 k 逼近归结为下面的迹极值问题：

$$\text{在 } \boldsymbol{Y}^{\top}\boldsymbol{Y} = \boldsymbol{I}_k \text{ 下最大化 } \operatorname{tr}(\boldsymbol{Y}^{\top}\boldsymbol{G}\boldsymbol{Y}), \qquad \boldsymbol{G} = \boldsymbol{A}\boldsymbol{A}^{\top}.$$

逐列套用 Rayleigh–Ritz 定理只能得到每一项不超过 $\lambda_1(\boldsymbol{G})$，即总和不超过 $k\lambda_1(\boldsymbol{G})$。这个界没有用到各列互相正交的约束，一般取不到：由定理 15.4的取等条件，总和等于 $k\lambda_1(\boldsymbol{G})$ 要求每个 $\boldsymbol{y}_l$ 都落在最大特征值的特征空间中；若 $\lambda_1(\boldsymbol{G})$ 单重，这个特征空间是一条直线，$k \ge 2$ 时容不下 k 个互相正交的单位向量。

先只比较由 $\boldsymbol{G}$ 的特征向量组成的子空间。设 $\boldsymbol{G}$ 的特征值为 $\lambda_1 \ge \cdots \ge \lambda_m$，对应标准正交特征向量 $\boldsymbol{q}_1, \dots, \boldsymbol{q}_m$。取 $\boldsymbol{Y} = [\boldsymbol{q}_{i_1}, \dots, \boldsymbol{q}_{i_k}]$（下标互不相同），则 $\boldsymbol{y}_l^{\top}\boldsymbol{G}\boldsymbol{y}_l = \lambda_{i_l}$，保留量为 $\lambda_{i_1} + \cdots + \lambda_{i_k}$；保留前 k 个特征方向给出最大的特征值和 $\sum_{i\le k}\lambda_i$。这给出一个明确的候选。任意倾斜的子空间会把权重分散到多个特征方向上，它是否仍不能超过这个值，需要下面的定理来回答。

回到示例 15.1，$\boldsymbol{G} = \operatorname{diag}(9, 4, 1)$，前两个特征方向张成 $\operatorname{span}\{\boldsymbol{e}_1, \boldsymbol{e}_2\}$，保留量 13，损失 1，正是三个坐标平面中最好的一个。一般地，由式 (5.3),

$\boldsymbol{A}\boldsymbol{A}^{\top}$ 的前 k 个特征方向可以取为左奇异向量 $\boldsymbol{u}_1,\dots,\boldsymbol{u}_k$，候选子空间就是 $\operatorname{span}\{\boldsymbol{u}_1,\dots,\boldsymbol{u}_k\}$。

同样的问题可以对任意实对称矩阵 $\boldsymbol{S}$ 提出：在 $\boldsymbol{Y}^{\top}\boldsymbol{Y}=\boldsymbol{I}_k$ 下，$\operatorname{tr}(\boldsymbol{Y}^{\top}\boldsymbol{S}\boldsymbol{Y})$ 能否超过前 k 个特征值之和，又能否低于后 k 个特征值之和？证明的想法是把迹写成特征值的加权和，看清正交约束对权重施加了什么限制。

定理 15.8　迹极值　设 $\boldsymbol{S}\in\mathbb{R}^{m\times m}$ 实对称，特征值 $\lambda_1\ge\cdots\ge\lambda_m$，对应标准正交特征向量 $\boldsymbol{q}_1,\dots,\boldsymbol{q}_m$，$1\le k\le m$。对满足 $\boldsymbol{Y}^{\top}\boldsymbol{Y}=\boldsymbol{I}_k$ 的 $\boldsymbol{Y}\in\mathbb{R}^{m\times k}$，

$$\sum_{i=m-k+1}^{m}\lambda_i\le\operatorname{tr}(\boldsymbol{Y}^{\top}\boldsymbol{S}\boldsymbol{Y})\le\sum_{i=1}^{k}\lambda_i, \tag{15.5}$$

上界由 $\boldsymbol{Y}=[\boldsymbol{q}_1,\dots,\boldsymbol{q}_k]$ 取到，下界由 $\boldsymbol{Y}=[\boldsymbol{q}_{m-k+1},\dots,\boldsymbol{q}_m]$ 取到。若 $k<m$ 且 $\lambda_k>\lambda_{k+1}$，则上界取等当且仅当 $\operatorname{range}(\boldsymbol{Y})=\operatorname{span}\{\boldsymbol{q}_1,\dots,\boldsymbol{q}_k\}$。

证明　由谱定理，$\boldsymbol{S}=\sum_i\lambda_i\boldsymbol{q}_i\boldsymbol{q}_i^{\top}$，故

$$\operatorname{tr}(\boldsymbol{Y}^{\top}\boldsymbol{S}\boldsymbol{Y})=\sum_{i=1}^{m}\lambda_i\operatorname{tr}(\boldsymbol{Y}^{\top}\boldsymbol{q}_i\boldsymbol{q}_i^{\top}\boldsymbol{Y})=\sum_{i=1}^{m}\lambda_i w_i,$$

其中 $w_i=\|\boldsymbol{Y}^{\top}\boldsymbol{q}_i\|_2^2$。权重受两条限制。第一，$\boldsymbol{P}=\boldsymbol{Y}\boldsymbol{Y}^{\top}$ 是到 $\operatorname{range}(\boldsymbol{Y})$ 的正交投影，$w_i=\boldsymbol{q}_i^{\top}\boldsymbol{P}\boldsymbol{q}_i=\boldsymbol{q}_i^{\top}\boldsymbol{P}^{\top}\boldsymbol{P}\boldsymbol{q}_i=\|\boldsymbol{P}\boldsymbol{q}_i\|_2^2$；正交投影不增加长度，所以 $0\le w_i\le\|\boldsymbol{q}_i\|_2^2=1$。第二，记 $\boldsymbol{Q}=[\boldsymbol{q}_1,\dots,\boldsymbol{q}_m]$，它是正交矩阵，右乘正交矩阵不改变 Frobenius 范数，于是

$$\sum_{i=1}^{m}w_i=\|\boldsymbol{Y}^{\top}\boldsymbol{Q}\|_{\mathrm{F}}^2=\|\boldsymbol{Y}^{\top}\|_{\mathrm{F}}^2=\operatorname{tr}(\boldsymbol{Y}^{\top}\boldsymbol{Y})=k.$$

也就是说，总量为 k 的权重分配给各个特征值，每个特征值至多分到 1。

直观上，要使加权和最大，应把权重全部放在最大的 k 个特征值上。用 λ_k 作为分界，可以把这一直观写成恒等式：

$$\sum_{i=1}^{m}\lambda_i w_i-\sum_{i=1}^{k}\lambda_i=\sum_{i\le k}(\lambda_i-\lambda_k)(w_i-1)+\sum_{i>k}(\lambda_i-\lambda_k)w_i+\lambda_k\Big(\sum_{i=1}^{m}w_i-k\Big).$$

展开右端即可核对。最后一项因 $\sum_i w_i=k$ 而为零。$i\le k$ 时 $\lambda_i-\lambda_k\ge 0$、$w_i-1\le 0$；$i>k$ 时 $\lambda_i-\lambda_k\le 0$、$w_i\ge 0$。所以右端每一项都不大于

零，上界成立。$\boldsymbol{Y} = [\boldsymbol{q}_1, \dots, \boldsymbol{q}_k]$ 时 w_i 在 $i \le k$ 时为 1、其余为 0，迹等于 $\sum_{i \le k} \lambda_i$。

取等条件也可以从这个恒等式读出。若 $\lambda_k > \lambda_{k+1}$，则 $i > k$ 时 $\lambda_i - \lambda_k < 0$，上界取等迫使 $w_i = 0$，即 $\boldsymbol{Y}^\top \boldsymbol{q}_i = \boldsymbol{0}$。于是 $\operatorname{range}(\boldsymbol{Y})$ 与 $\boldsymbol{q}_{k+1}, \dots, \boldsymbol{q}_m$ 都正交，含于 $\operatorname{span}\{\boldsymbol{q}_1, \dots, \boldsymbol{q}_k\}$；两者都是 k 维的，所以相等。反之，若 $\operatorname{range}(\boldsymbol{Y}) = \operatorname{span}\{\boldsymbol{q}_1, \dots, \boldsymbol{q}_k\}$，则 $i \le k$ 时 $\boldsymbol{P}\boldsymbol{q}_i = \boldsymbol{q}_i$、$i > k$ 时 $\boldsymbol{P}\boldsymbol{q}_i = \boldsymbol{0}$，迹等于上界。

下界由上界得到。$-\boldsymbol{S}$ 的特征值按降序为 $-\lambda_m \ge \cdots \ge -\lambda_1$，对应特征向量依次为 $\boldsymbol{q}_m, \dots, \boldsymbol{q}_1$。对 $-\boldsymbol{S}$ 应用上界，得 $-\operatorname{tr}(\boldsymbol{Y}^\top \boldsymbol{S}\boldsymbol{Y}) \le -\sum_{i=m-k+1}^{m} \lambda_i$，等号在 $\boldsymbol{Y} = [\boldsymbol{q}_{m-k+1}, \dots, \boldsymbol{q}_m]$ 时成立。 ■

回到低秩逼近，取 $\boldsymbol{S} = \boldsymbol{G} = \boldsymbol{A}\boldsymbol{A}^\top$。它的特征值是 $\sigma_1^2 \ge \cdots \ge \sigma_r^2$，再补上 $m - r$ 个零；$k < r$ 时前 k 个之和为 $\sum_{i \le k} \sigma_i^2$。于是任意 k 维子空间最多保留 $\sum_{i=1}^{k} \sigma_i^2$，式 (15.4)右端的最大值存在，并由 $\operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_k\}$ 取到。在示例 15.1中，这确认任意倾斜平面的保留量都不超过 13，坐标平面 $\operatorname{span}\{\boldsymbol{e}_1, \boldsymbol{e}_2\}$ 已是最优的平面。

对一般的对称矩阵 $\boldsymbol{S}$，迹极值界照样成立，但只有在当前这种半正定的 Gram 情形，迹才表示投影保留的长度平方。下一小节把最优子空间上的投影重建写成具体的矩阵。

15.3.2 截断 SVD 的构造

主要思想 设 $\boldsymbol{A}$ 的奇异值分解写成和式 (5.1)，$\boldsymbol{A} = \sum_{i=1}^{r} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^\top$，其中 $r = \operatorname{rank} \boldsymbol{A}$，$\sigma_1 \ge \cdots \ge \sigma_r > 0$。上一小节说明，$1 \le k < r$ 时最优子空间可取为 $\operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_k\}$，即 $\boldsymbol{Y} = \boldsymbol{U}_k = [\boldsymbol{u}_1, \dots, \boldsymbol{u}_k]$。由 $\boldsymbol{U}_k^\top \boldsymbol{u}_i$ 在 $i \le k$ 时等于 $\boldsymbol{e}_i$、在 $i > k$ 时等于 $\boldsymbol{0}$，这个子空间上的最优重建是

$$\begin{aligned} \boldsymbol{U}_k \boldsymbol{U}_k^\top \boldsymbol{A} &= \sum_{i=1}^{r} \sigma_i \boldsymbol{U}_k (\boldsymbol{U}_k^\top \boldsymbol{u}_i) \boldsymbol{v}_i^\top \\ &= \sum_{i=1}^{k} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^\top . \end{aligned}$$

也就是说，把 $\boldsymbol{A}$ 的各列正交投影到前 k 个左奇异方向上，等于只保留 SVD 和式的前 k 项。

把这个由子空间优化推导出的矩阵记下来。对整数 $k \ge 0$，称

$$\boldsymbol{A}_k = \sum_{i=1}^{\min(k,r)} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^\top = \boldsymbol{U}_k \boldsymbol{\Sigma}_k \boldsymbol{V}_k^\top \qquad (15.6)$$

$$k \ge 0$$

为 $\boldsymbol{A}$ 的**截断 SVD**（truncated SVD），其中 $k \le r$ 时 $\boldsymbol{\Sigma}_k = \operatorname{diag}(\sigma_1, \dots, \sigma_k)$，$\boldsymbol{V}_k = [\boldsymbol{v}_1, \dots, \boldsymbol{v}_k]$。两种边界情形与第 15.1节的直接回答一致：$k = 0$ 时和式为空，$\boldsymbol{A}_0 = \boldsymbol{0}$；$k \ge r$ 时保留了全部项，$\boldsymbol{A}_k = \boldsymbol{A}$。

$k \le r$ 时，$\boldsymbol{A}_k \boldsymbol{v}_i = \sigma_i \boldsymbol{u}_i$（$i \le k$），而 $\boldsymbol{A}_k$ 与 $\boldsymbol{v}_{k+1}, \dots, \boldsymbol{v}_d$ 的作用为零，所以列空间恰为 $\operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_k\}$，$\operatorname{rank} \boldsymbol{A}_k = k$，满足秩约束。

算法实现与算例　给定已经求出的 SVD，截断 SVD 的计算分三步。第一，核对 k 是满足 $0 \le k \le \min(m, d)$ 的整数，$k \ge r$ 时直接返回 $\boldsymbol{A}$，$k = 0$ 时返回零矩阵。第二，按奇异值非增的顺序读取前 k 个奇异值及配对的左右奇异向量；配对不能打乱，因为每一项 $\sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^{\top}$ 都要求 $\boldsymbol{A}\boldsymbol{v}_i = \sigma_i \boldsymbol{u}_i$。第三，求外积和。若只需要压缩存储，就保留 $\boldsymbol{U}_k$、$\sigma_1, \dots, \sigma_k$ 与 $\boldsymbol{V}_k$ 三个小因子，不必形成 $m \times d$ 的矩阵；需要核验时，再由因子相乘求出重建误差。

示例 15.9　对角矩阵的截断　仍取 $\boldsymbol{A} = \operatorname{diag}(3, 2, 1)$，奇异值为 $3, 2, 1$，可取 $\boldsymbol{u}_i = \boldsymbol{v}_i = \boldsymbol{e}_i$。截断得

$$\boldsymbol{A}_1 = \operatorname{diag}(3, 0, 0), \qquad \boldsymbol{A}_2 = \operatorname{diag}(3, 2, 0).$$

$\boldsymbol{A} - \boldsymbol{A}_1 = \operatorname{diag}(0, 2, 1)$，平方误差 $2^2 + 1^2 = 5$，谱范数误差 2；$\boldsymbol{A} - \boldsymbol{A}_2 = \operatorname{diag}(0, 0, 1)$，平方误差 1，谱范数误差 1。平方误差 1 正是示例 15.1中最佳坐标平面 $\operatorname{span}\{\boldsymbol{e}_1, \boldsymbol{e}_2\}$ 的损失；平方误差 $5 = 4 + 1$ 也正是只保留 $\boldsymbol{e}_1$ 这条坐标直线时的损失。那里留下的问题已由上一小节的迹极值界回答：任何二维子空间保留的长度平方都不超过 $9 + 4$，倾斜的平面不会更好。

对角矩阵的奇异方向就是坐标方向。下面的例子中奇异方向是倾斜的，而且有两个相等的奇异值，可以看到截断位置处的重奇异值带来的变化。

示例 15.10　有重奇异值的三阶截断　取

$$\boldsymbol{A} = \begin{bmatrix} 3 & 2 & 0 \\ 2 & 3 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

先核验奇异方向。令 $\boldsymbol{u}_1 = (1, 1, 0)^{\top}/\sqrt{2}$、$\boldsymbol{u}_2 = (1, -1, 0)^{\top}/\sqrt{2}$、$\boldsymbol{u}_3 = (0, 0, 1)^{\top}$，它们标准正交，且 $\boldsymbol{A}\boldsymbol{u}_1 = 5\boldsymbol{u}_1$、$\boldsymbol{A}\boldsymbol{u}_2 = \boldsymbol{u}_2$、$\boldsymbol{A}\boldsymbol{u}_3 = \boldsymbol{u}_3$。$\boldsymbol{A}$ 对称、特征值非负，所以可取 $\boldsymbol{v}_i = \boldsymbol{u}_i$，奇异值为 $5, 1, 1$。

取 $k=1$，

$$\boldsymbol{A}_1 = 5\boldsymbol{u}_1\boldsymbol{u}_1^{\top} = \frac{5}{2}\begin{bmatrix}1&1&0\\1&1&0\\0&0&0\end{bmatrix}, \qquad \boldsymbol{A}-\boldsymbol{A}_1 = \begin{bmatrix}1/2&-1/2&0\\-1/2&1/2&0\\0&0&1\end{bmatrix}.$$

左上四项均为 $5/2$，其余为零。残差的 Frobenius 范数平方为 $4\times\frac{1}{4}+1=2$，即 $\|\boldsymbol{A}-\boldsymbol{A}_1\|_{\mathrm{F}}=\sqrt{2}$。残差等于 $\boldsymbol{u}_2\boldsymbol{u}_2^{\top}+\boldsymbol{u}_3\boldsymbol{u}_3^{\top}$，是到 $\operatorname{span}\{\boldsymbol{u}_2,\boldsymbol{u}_3\}$ 的正交投影，它把该平面内的单位向量原样送出，把 $\boldsymbol{u}_1$ 送到零，所以谱范数为 1。

取 $k=2$ 并保留第二方向，得到

$$\boldsymbol{A}_2 = \boldsymbol{A}_1 + \boldsymbol{u}_2\boldsymbol{u}_2^{\top} = \begin{bmatrix}3&2&0\\2&3&0\\0&0&0\end{bmatrix}, \qquad \boldsymbol{A}-\boldsymbol{A}_2 = \boldsymbol{e}_3\boldsymbol{e}_3^{\top},$$

残差的两种范数都是 1。由于 $\sigma_2=\sigma_3$，把 $\boldsymbol{u}_2$ 与 $\boldsymbol{u}_3$ 的次序交换也是 $\boldsymbol{A}$ 的一个 SVD，按它截断得到 $\boldsymbol{A}_2' = \boldsymbol{A}_1+\boldsymbol{u}_3\boldsymbol{u}_3^{\top}$，残差 $\boldsymbol{u}_2\boldsymbol{u}_2^{\top}$ 的两种范数同样为 1。$\boldsymbol{A}_2\neq\boldsymbol{A}_2'$ 而误差相同，这预示截断位置处奇异值重复时最优矩阵不唯一。

图 15.2画出截断的几何：单位圆经 $\boldsymbol{A}$ 变成椭圆，秩一近似把椭圆压成主轴方向的线段，残留的谱范数误差恰为舍弃的 σ_2。

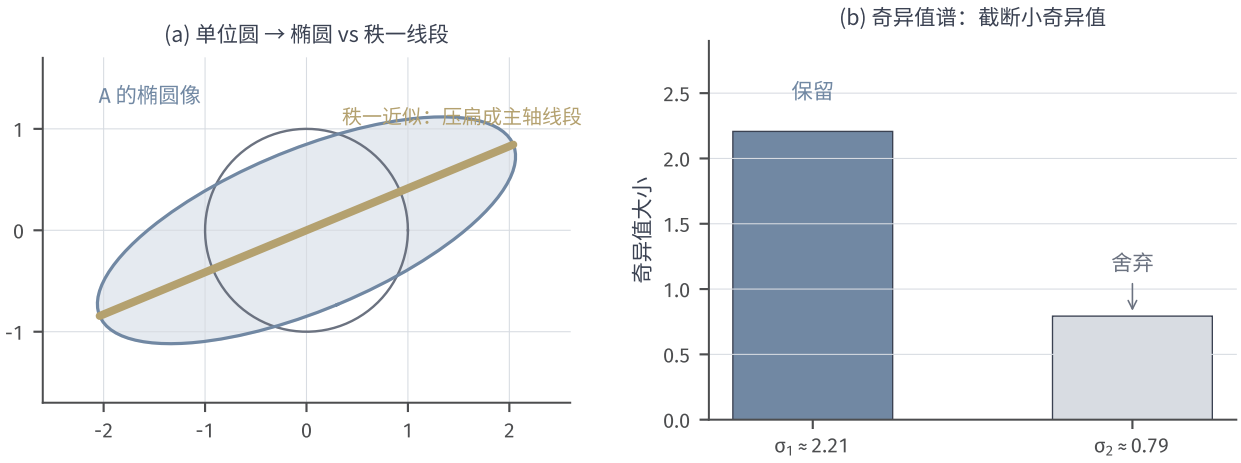


图 15.2　低秩截断的几何。$\boldsymbol{A}=\left[\begin{smallmatrix}2&0.5\\0.5&1\end{smallmatrix}\right]$，灰圆为单位圆，蓝椭圆为 $\boldsymbol{A}$ 的像。左：黄粗线段为秩一近似 $\boldsymbol{A}_1=\sigma_1\boldsymbol{v}_1\boldsymbol{v}_1^{\top}$ 的像，椭圆被压成长 $2\sigma_1$ 的线段；右：$\sigma_1\approx 2.21$（保留）、$\sigma_2\approx 0.79$（舍弃），算子范数误差 $\|\boldsymbol{A}-\boldsymbol{A}_1\|_2=\sigma_2$。$\sigma_{1,2}=(3\pm\sqrt{2})/2$。固定复算。

算法分析 截断 SVD 的好处还在于表示代价。直接存储 $\boldsymbol{A}$ 需要 md 个数；保存因子 $\boldsymbol{U}_k$、$\sigma_1,\dots,\sigma_k$ 与 $\boldsymbol{V}_k$ 只需 $k(m+d+1)$ 个数。按 $\boldsymbol{A}_k\boldsymbol{x}=\boldsymbol{U}_k\big(\boldsymbol{\Sigma}_k(\boldsymbol{V}_k^{\top}\boldsymbol{x})\big)$ 的顺序乘向量，依次需要约 dk、k、mk 次乘法，共 $O(k(m+d))$ 次运算，而直接用 $\boldsymbol{A}$ 乘向量需要 $O(md)$ 次。例如 $m=d=1000$、$k=10$ 时，存储由 10^6 个数降为 20010 个数。

这些是表示与后续作用的代价，不包括计算 SVD 本身的代价；后者取决于所用的数值算法，本书不作分析。还要注意用途：第 14章的截断 SVD 求解也用到 $\boldsymbol{A}_k$，但那里是用它的伪逆稳定地求解方程；这里 $\boldsymbol{A}_k$ 本身就是要评价的近似对象，评价标准是重建误差。

15.3.3 最佳误差与最优性

先计算截断 SVD 的实际误差，再比较全部秩不超过 k 的候选。设 $0\le k<r$。余下的 $\boldsymbol{A}-\boldsymbol{A}_k=\sum_{i>k}\sigma_i\boldsymbol{u}_i\boldsymbol{v}_i^{\top}$ 仍由两组标准正交向量和降序的正系数 $\sigma_{k+1}\ge\cdots\ge\sigma_r$ 组成，可以照第 5.3节的方法读出它的大小。

对 $\boldsymbol{x}=\sum_{i=1}^{d}c_i\boldsymbol{v}_i$，$(\boldsymbol{A}-\boldsymbol{A}_k)\boldsymbol{x}=\sum_{i=k+1}^{r}\sigma_i c_i\boldsymbol{u}_i$，由 $\boldsymbol{u}_i$ 标准正交，

$$\|(\boldsymbol{A}-\boldsymbol{A}_k)\boldsymbol{x}\|_2^2=\sum_{i=k+1}^{r}\sigma_i^2c_i^2\le\sigma_{k+1}^2\|\boldsymbol{x}\|_2^2,$$

等号在 $\boldsymbol{x}=\boldsymbol{v}_{k+1}$ 时成立。又由 $\boldsymbol{u}_i^{\top}\boldsymbol{u}_j=\delta_{i,j}$，$(\boldsymbol{A}-\boldsymbol{A}_k)^{\top}(\boldsymbol{A}-\boldsymbol{A}_k)=\sum_{i>k}\sigma_i^2\boldsymbol{v}_i\boldsymbol{v}_i^{\top}$，取迹得 Frobenius 范数平方 $\sum_{i>k}\sigma_i^2$。于是

$$\begin{aligned}\|\boldsymbol{A}-\boldsymbol{A}_k\|_2&=\sigma_{k+1}\\ \|\boldsymbol{A}-\boldsymbol{A}_k\|_{\mathrm{F}}&=\Big(\sum_{i=k+1}^{r}\sigma_i^2\Big)^{1/2}.\end{aligned}\tag{15.7}$$

Frobenius 平方误差也可以由引理 15.7读出：$\|\boldsymbol{A}\|_{\mathrm{F}}^2-\operatorname{tr}(\boldsymbol{U}_k^{\top}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{U}_k)=\sum_{i\le r}\sigma_i^2-\sum_{i\le k}\sigma_i^2$。示例 15.10中 $k=1$ 时，式 (15.7)给出 $\sqrt{1^2+1^2}=\sqrt{2}$ 与 $\sigma_2=1$，与直接计算一致。

两种误差记录的内容不同：Frobenius 平方误差汇总所有舍弃方向，谱范数误差只记录最坏的单位输入方向。式 (15.7)只是这一构造的误差，尚需证明其他秩不超过 k 的矩阵不能更小。Frobenius 范数的结论由上一小节的化归和迹极值得到；谱范数不能这样处理，因为 $\|\boldsymbol{M}\|_2\le\|\boldsymbol{M}\|_{\mathrm{F}}$，Frobenius 误差的下界推不出谱范数误差的下界，需要另作证明。

定理 15.11 Eckart–Young–Mirsky 最佳低秩逼近 设 $\boldsymbol{A} \in \mathbb{R}^{m\times d}$ 的秩为 r，奇异值为 $\sigma_1 \geq \cdots \geq \sigma_r > 0$。对 $0 \leq k < r$，

$$\min_{\operatorname{rank}\boldsymbol{X}\leq k} \|\boldsymbol{A}-\boldsymbol{X}\|_2 = \sigma_{k+1}, \tag{15.8}$$

$$\min_{\operatorname{rank}\boldsymbol{X}\leq k} \|\boldsymbol{A}-\boldsymbol{X}\|_{\mathrm{F}} = \Big(\sum_{i=k+1}^{r} \sigma_i^2\Big)^{1/2}, \tag{15.9}$$

两个最小值都由截断 SVD $\boldsymbol{A}_k$ 达到。

证明 由式 (15.7)，$\boldsymbol{A}_k$ 的两种误差恰为右端，只需证明任意秩不超过 k 的 $\boldsymbol{X}$ 误差都不更小。$k=0$ 时只有 $\boldsymbol{X}=\boldsymbol{0}$，结论即式 (15.7)，下设 $k \geq 1$。

Frobenius 情形。按第 15.3.1节的做法，把 $\boldsymbol{X}$ 的列空间补成一个 k 维子空间，取其标准正交基组成 $\boldsymbol{Y}$，则 $\boldsymbol{X} = \boldsymbol{Y}\boldsymbol{C}$。由引理 15.7、定理 15.8与式 (5.6)，

$$\begin{aligned}\|\boldsymbol{A}-\boldsymbol{X}\|_{\mathrm{F}}^2 &\geq \|\boldsymbol{A}\|_{\mathrm{F}}^2 - \operatorname{tr}(\boldsymbol{Y}^{\mathsf{T}}\boldsymbol{A}\boldsymbol{A}^{\mathsf{T}}\boldsymbol{Y}) \\ &\geq \sum_{i=1}^{r}\sigma_i^2 - \sum_{i=1}^{k}\sigma_i^2 = \sum_{i=k+1}^{r}\sigma_i^2.\end{aligned}$$

谱范数情形。由秩零度定理 2.26，$\dim\ker\boldsymbol{X} = d - \operatorname{rank}\boldsymbol{X} \geq d-k$。子空间 $\operatorname{span}\{\boldsymbol{v}_1,\dots,\boldsymbol{v}_{k+1}\}$ 的维数为 $k+1$（$k+1 \leq r \leq d$）。两者维数之和超过 d，由维数公式，它们有非零公共向量；取其中的单位向量 $\boldsymbol{x} = \sum_{i=1}^{k+1} c_i\boldsymbol{v}_i$，$\sum_i c_i^2 = 1$。由 $\boldsymbol{X}\boldsymbol{x}=\boldsymbol{0}$，

$$\|(\boldsymbol{A}-\boldsymbol{X})\boldsymbol{x}\|_2 = \|\boldsymbol{A}\boldsymbol{x}\|_2 = \Big(\sum_{i=1}^{k+1}\sigma_i^2 c_i^2\Big)^{1/2} \geq \sigma_{k+1}, \tag{15.10}$$

所以 $\|\boldsymbol{A}-\boldsymbol{X}\|_2 \geq \sigma_{k+1}$。 ■

这一结论最早由 Eckart 与 Young 给出[1]。定理覆盖任意秩不超过 k 的矩阵，而不只覆盖事先选定的投影形式：Frobenius 情形借助第 15.3.1节的化归把任意候选归入某个子空间，谱范数情形则直接利用候选矩阵的核。两种范数下的最小误差都由舍弃的奇异值决定：谱范数看最大的舍弃值 σ_{k+1}，Frobenius 范数看全部舍弃值的平方和。

[1] C. Eckart, G. Young, *The Approximation of One Matrix by Another of Lower Rank* In Psychometrika, 1936, vol. 1, no. 3, pp. 211–218

15.3.4 最优解的唯一性

最小误差唯一,达到最小误差的矩阵却未必唯一。在有效的秩预算 $1 \le k < r$ 下，Frobenius 情形的唯一性由迹极值的取等条件决定，关键是截断位置两侧的奇异值是否有间隙。

定理 15.12 Frobenius 最佳逼近的唯一性 设 $1 \le k < r$ 且 $\sigma_k > \sigma_{k+1}$，则 $\boldsymbol{A}_k$ 是 $\min_{\operatorname{rank}\boldsymbol{X}\le k}\|\boldsymbol{A}-\boldsymbol{X}\|_{\mathrm{F}}$ 的唯一最优解。

证明 设 $\boldsymbol{X}$ 达到最小值，按定理 15.11的证明取 $\boldsymbol{Y}$，写 $\boldsymbol{X} = \boldsymbol{Y}\boldsymbol{C}$。证明中的两个不等号都须取等。第一个取等，由式 (15.3)得 $\boldsymbol{C} = \boldsymbol{Y}^{\top}\boldsymbol{A}$，即 $\boldsymbol{X} = \boldsymbol{Y}\boldsymbol{Y}^{\top}\boldsymbol{A}$。第二个取等，即 $\operatorname{tr}(\boldsymbol{Y}^{\top}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{Y}) = \sum_{i\le k}\sigma_i^2$。$\boldsymbol{A}\boldsymbol{A}^{\top}$ 的第 k 与第 $k+1$ 个特征值为 $\sigma_k^2 > \sigma_{k+1}^2$，由定理 15.8的取等条件，$\operatorname{range}(\boldsymbol{Y}) = \operatorname{span}\{\boldsymbol{u}_1,\dots,\boldsymbol{u}_k\}$。到同一子空间的正交投影是同一个矩阵，故 $\boldsymbol{Y}\boldsymbol{Y}^{\top} = \boldsymbol{U}_k\boldsymbol{U}_k^{\top}$，从而 $\boldsymbol{X} = \boldsymbol{U}_k\boldsymbol{U}_k^{\top}\boldsymbol{A} = \boldsymbol{A}_k$。 ■

$k = 1$ 时，条件 $\sigma_1 > \sigma_2$ 正是第 15.2.3节秩一最优解唯一的条件。间隙条件也确定了 $\boldsymbol{A}_k$ 本身：$\sigma_k > \sigma_{k+1}$ 时，$\operatorname{span}\{\boldsymbol{u}_1,\dots,\boldsymbol{u}_k\}$ 是 $\boldsymbol{A}\boldsymbol{A}^{\top}$ 前 k 个特征值对应的特征空间之和，不随 SVD 的选取改变，$\boldsymbol{A}_k = \boldsymbol{U}_k\boldsymbol{U}_k^{\top}\boldsymbol{A}$ 也就与所选的奇异向量无关。

截断跨过相等的正奇异值时，唯一性失败。例如 $\boldsymbol{A} = \operatorname{diag}(2,1,1)$、$k = 2$，$\operatorname{diag}(2,1,0)$ 与 $\operatorname{diag}(2,0,1)$ 的平方误差都是 1；这时“前 k 个奇异向量”本身就有不同选法，每种选法给出一个最优矩阵。示例 15.10中 $k = 2$ 的 $\boldsymbol{A}_2$ 与 $\boldsymbol{A}_2'$ 也是这种情形。

谱范数下的最优矩阵即使有间隙也不唯一，所以间隙条件不能直接当成谱范数的唯一性保证。先说明对角矩阵的谱范数：$\boldsymbol{D} = \operatorname{diag}(a_1,\dots,a_m)$ 满足 $\|\boldsymbol{D}\boldsymbol{x}\|_2^2 = \sum_i a_i^2x_i^2 \le \max_i a_i^2\|\boldsymbol{x}\|_2^2$，在绝对值最大的对角元所在的坐标向量处取等，故 $\|\boldsymbol{D}\|_2 = \max_i|a_i|$。取 $\boldsymbol{A} = \operatorname{diag}(3,2,1)$、$k = 1$，$\boldsymbol{X} = \operatorname{diag}(t,0,0)$ 给出 $\|\boldsymbol{A}-\boldsymbol{X}\|_2 = \max(|3-t|,2)$，$1 \le t \le 5$ 时都等于小值 2，尽管 $\sigma_1 = 3 > \sigma_2 = 2$。谱范数只看最坏方向，最坏方向之外的偏差在一定范围内可以随意改变。

边界情形 $k = 0$ 与 $k \ge r$ 已在第 15.1节回答，最优矩阵分别是 $\boldsymbol{0}$ 与 $\boldsymbol{A}$ 本身，不需要套用间隙判据。

本节的最优性依赖两个前提：允许集合是全部秩不超过 k 的矩阵，误差是谱范数或 Frobenius 范数。额外要求近似矩阵非负或因子稀疏时，允许集合缩小，$\boldsymbol{A}_k$ 可能不再可行。改用逐元素加权的平方误差 $\sum_{i,j} w_{i,j}(a_{i,j}-x_{i,j})^2$ 时，误差一般不再按正交投影分解，引理 15.7失效。这些情形下截断 SVD

一般不再是最优解，最优性需要重新论证；下一节处理其中能够化归的一类加权误差。

15.4 加权逼近与广义 Rayleigh 商

前两节都用欧氏长度：单位方向按 $\boldsymbol{u}^{\top}\boldsymbol{u}=1$ 规定，重建误差按各元素平方和计算。各坐标的单位或重要性不同时，长度往往按第 3章的加权内积度量。度量一变，有两处跟着改变：规定“单位方向”的长度变了，比较重建误差的标准也变了。

本节先处理前一处：保持二次型不变，改用加权长度规定单位方向，得到广义 Rayleigh 商及其极值。再处理后一处：在行、列权重可以分离的误差下研究低秩逼近，并看到它的最佳方向正是由广义 Rayleigh 商选出的。广义 Rayleigh 商还为后面的图谱松弛提供工具：卷九的谱划分把平衡约束写成按顶点度加权的长度，再用广义 Rayleigh 商的极值给出离散划分问题的松弛下界，可参考卷九第 12 章“谱划分”。

15.4.1 广义 Rayleigh 商的极值

保持 $\boldsymbol{S}=\operatorname{diag}(4,1)$ 不变，改用 $\boldsymbol{B}=\operatorname{diag}(9,1)$ 规定长度，即要求 $\boldsymbol{x}^{\top}\boldsymbol{B}\boldsymbol{x}=9x_1^2+x_2^2=1$。沿第一坐标方向，满足约束的向量是 $\pm\boldsymbol{e}_1/3$，二次型值为 $4\cdot(1/3)^2=4/9$；沿第二坐标方向，满足约束的向量仍是 $\pm\boldsymbol{e}_2$，值为 1。在欧氏约束下最优的 $\boldsymbol{e}_1$ 方向，现在不如 $\boldsymbol{e}_2$ 方向。

可见改变长度标准会改变答案。而且与示例 15.5之前的讨论一样，比较两个坐标方向还不够，必须比较全部满足加权约束的方向。与欧氏情形相同，先把约束化为一个不随缩放改变的商。

定义 15.13　广义 Rayleigh 商　设 $\boldsymbol{S}\in\mathbb{R}^{d\times d}$ 对称，$\boldsymbol{B}\in\mathbb{R}^{d\times d}$ 对称正定。对 $\boldsymbol{x}\neq\boldsymbol{0}$，称

$$R_{\boldsymbol{S},\boldsymbol{B}}(\boldsymbol{x})=\frac{\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}}{\boldsymbol{x}^{\top}\boldsymbol{B}\boldsymbol{x}} \tag{15.11}$$

为 $\boldsymbol{S}$ 关于 $\boldsymbol{B}$ 的广义 Rayleigh 商（generalized Rayleigh quotient）。

$\boldsymbol{B}$ 正定保证分母 $\boldsymbol{x}^{\top}\boldsymbol{B}\boldsymbol{x}$ 对一切 $\boldsymbol{x}\neq\boldsymbol{0}$ 为正，商有定义。把 $\boldsymbol{x}$ 换成 $c\boldsymbol{x}$（$c\neq0$）时分子分母同乘 c^2，商不变。对任意 $\boldsymbol{x}\neq\boldsymbol{0}$，令 $\boldsymbol{u}=\boldsymbol{x}/\sqrt{\boldsymbol{x}^{\top}\boldsymbol{B}\boldsymbol{x}}$，则 $\boldsymbol{u}^{\top}\boldsymbol{B}\boldsymbol{u}=1$ 且 $R_{\boldsymbol{S},\boldsymbol{B}}(\boldsymbol{x})=\boldsymbol{u}^{\top}\boldsymbol{S}\boldsymbol{u}$；反过来，约束 $\boldsymbol{x}^{\top}\boldsymbol{B}\boldsymbol{x}=1$ 上的二次型值就是广义 Rayleigh 商。所以求广义 Rayleigh 商的极值，等价于在 $\boldsymbol{x}^{\top}\boldsymbol{B}\boldsymbol{x}=1$ 上比较 $\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}$。

$\boldsymbol{B}=\boldsymbol{I}$ 时，广义 Rayleigh 商恰好回到普通 Rayleigh 商。两者比较的是同一个二次型 $\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}$，差别只在于用哪种长度规定“单位输入”：普通 Rayleigh 商用欧氏长度，广义 Rayleigh 商用加权长度 $\|\boldsymbol{x}\|_{\boldsymbol{B}}$。

主要思想 加权约束 $\boldsymbol{x}^{\top}\boldsymbol{B}\boldsymbol{x}=1$ 的困难在于它不是欧氏单位球面,第 15.2.2节的结论不能直接使用。思路是换一个坐标，使加权长度在新坐标中成为欧氏长度。由定理 3.52，正定的 $\boldsymbol{B}$ 可以写成 $\boldsymbol{B}=\boldsymbol{L}^{\top}\boldsymbol{L}$，其中 $\boldsymbol{L}$ 可逆。令 $\boldsymbol{z}=\boldsymbol{L}\boldsymbol{x}$，则 $\boldsymbol{x}=\boldsymbol{L}^{-1}\boldsymbol{z}$，且 $\boldsymbol{x}\neq\boldsymbol{0}$ 当且仅当 $\boldsymbol{z}\neq\boldsymbol{0}$。代入得

$$\boldsymbol{x}^{\top}\boldsymbol{B}\boldsymbol{x}=(\boldsymbol{L}\boldsymbol{x})^{\top}(\boldsymbol{L}\boldsymbol{x})=\boldsymbol{z}^{\top}\boldsymbol{z},\qquad \boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}=\boldsymbol{z}^{\top}\boldsymbol{L}^{-\top}\boldsymbol{S}\boldsymbol{L}^{-1}\boldsymbol{z},$$

其中 $\boldsymbol{L}^{-\top}$ 表示 $(\boldsymbol{L}^{-1})^{\top}$。记

$$\boldsymbol{C}=\boldsymbol{L}^{-\top}\boldsymbol{S}\boldsymbol{L}^{-1},$$

则 $\boldsymbol{C}^{\top}=\boldsymbol{L}^{-\top}\boldsymbol{S}^{\top}\boldsymbol{L}^{-1}=\boldsymbol{C}$，仍是实对称矩阵，而

$$R_{\boldsymbol{S},\boldsymbol{B}}(\boldsymbol{x})=\frac{\boldsymbol{z}^{\top}\boldsymbol{C}\boldsymbol{z}}{\boldsymbol{z}^{\top}\boldsymbol{z}}=R_{\boldsymbol{C}}(\boldsymbol{L}\boldsymbol{x}).$$

加权约束问题就化成了 $\boldsymbol{C}$ 的普通 Rayleigh 商问题, 可以直接应用定理 15.4。这一化归只用到 Gram 因子与换元，不需要矩阵平方根、多元微分或 Lagrange 乘子法。

最优方向要从新坐标换回原坐标。若 $\boldsymbol{C}\boldsymbol{z}=\mu\boldsymbol{z}$, 令 $\boldsymbol{v}=\boldsymbol{L}^{-1}\boldsymbol{z}$, 则 $\boldsymbol{L}^{-\top}\boldsymbol{S}\boldsymbol{v}=\mu\boldsymbol{L}\boldsymbol{v}$，两边左乘 $\boldsymbol{L}^{\top}$ 得

$$\boldsymbol{S}\boldsymbol{v}=\mu\boldsymbol{L}^{\top}\boldsymbol{L}\boldsymbol{v}=\mu\boldsymbol{B}\boldsymbol{v}.$$

反过来，若 $\boldsymbol{S}\boldsymbol{v}=\mu\boldsymbol{B}\boldsymbol{v}$ 且 $\boldsymbol{v}\neq\boldsymbol{0}$，左乘 $\boldsymbol{L}^{-\top}$ 并令 $\boldsymbol{z}=\boldsymbol{L}\boldsymbol{v}$，就得到 $\boldsymbol{C}\boldsymbol{z}=\mu\boldsymbol{z}$。所以，$\boldsymbol{C}$ 的特征对与下面方程的解一一对应。

定义 15.14 广义特征值 对实对称 $\boldsymbol{S}$ 与对称正定 $\boldsymbol{B}$，称满足

$$\boldsymbol{S}\boldsymbol{v}=\mu\boldsymbol{B}\boldsymbol{v},\qquad \boldsymbol{v}\neq\boldsymbol{0} \tag{15.12}$$

的 μ 为广义特征值，$\boldsymbol{v}$ 为属于 μ 的广义特征向量，求解它们的问题称为**广义特征问题**（generalized eigenvalue problem）。

广义特征值不依赖 Gram 因子 $\boldsymbol{L}$ 的选取。由 $\boldsymbol{S}-\mu\boldsymbol{B}=\boldsymbol{L}^{\top}(\boldsymbol{C}-\mu\boldsymbol{I})\boldsymbol{L}$,

$$\det(\boldsymbol{S}-\mu\boldsymbol{B})=(\det\boldsymbol{L})^{2}\det(\boldsymbol{C}-\mu\boldsymbol{I}),$$

而 $\det\boldsymbol{L}\neq 0$，所以广义特征值恰是 $\det(\boldsymbol{S}-\mu\boldsymbol{B})=0$ 的根，也就是 $\boldsymbol{C}$ 的特征值；不同的 $\boldsymbol{L}$ 给出不同的 $\boldsymbol{C}$，特征值却相同。

$\boldsymbol{C}$ 对称，由谱定理，这些根全是实数，按重数计共有 d 个，下面记为 $\mu_1\geq\cdots\geq\mu_d$。把定理 15.4用于 $\boldsymbol{C}$ 并换回原坐标，就得到加权约束问题的解。

定理 15.15　广义 Rayleigh 商的极值　设 $\boldsymbol{S}$ 对称、$\boldsymbol{B}$ 对称正定，广义特征值为 $\mu_1 \geq \cdots \geq \mu_d$。则对一切 $\boldsymbol{x} \neq \boldsymbol{0}$，

$$\mu_d \leq R_{\boldsymbol{S},\boldsymbol{B}}(\boldsymbol{x}) \leq \mu_1.$$

$R_{\boldsymbol{S},\boldsymbol{B}}(\boldsymbol{x}) = \mu_1$ 当且仅当 $\boldsymbol{S}\boldsymbol{x} = \mu_1 \boldsymbol{B}\boldsymbol{x}$，$R_{\boldsymbol{S},\boldsymbol{B}}(\boldsymbol{x}) = \mu_d$ 当且仅当 $\boldsymbol{S}\boldsymbol{x} = \mu_d \boldsymbol{B}\boldsymbol{x}$。因此，在约束 $\boldsymbol{x}^{\top}\boldsymbol{B}\boldsymbol{x} = 1$ 上，$\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}$ 的最大值为 μ_1，最优解是满足 $\boldsymbol{v}^{\top}\boldsymbol{B}\boldsymbol{v} = 1$ 的属于 μ_1 的广义特征向量；最小值的情形相同。

证明　取 $\boldsymbol{B} = \boldsymbol{L}^{\top}\boldsymbol{L}$ 与 $\boldsymbol{C} = \boldsymbol{L}^{-\top}\boldsymbol{S}\boldsymbol{L}^{-1}$ 如上。$\boldsymbol{C}$ 的特征值就是 $\mu_1 \geq \cdots \geq \mu_d$。对 $\boldsymbol{x} \neq \boldsymbol{0}$，令 $\boldsymbol{z} = \boldsymbol{L}\boldsymbol{x} \neq \boldsymbol{0}$，由 $R_{\boldsymbol{S},\boldsymbol{B}}(\boldsymbol{x}) = R_{\boldsymbol{C}}(\boldsymbol{z})$ 及定理 15.4，得 $\mu_d \leq R_{\boldsymbol{S},\boldsymbol{B}}(\boldsymbol{x}) \leq \mu_1$。

同一定理还说明，$R_{\boldsymbol{C}}(\boldsymbol{z}) = \mu_1$ 当且仅当 $\boldsymbol{C}\boldsymbol{z} = \mu_1 \boldsymbol{z}$。由上面的一一对应，这又当且仅当 $\boldsymbol{S}\boldsymbol{x} = \mu_1 \boldsymbol{B}\boldsymbol{x}$。$\boldsymbol{C}$ 确有属于 μ_1 的特征向量，所以上界能够取到。最小值同理。

最后，约束 $\boldsymbol{x}^{\top}\boldsymbol{B}\boldsymbol{x} = 1$ 上的二次型值就是广义 Rayleigh 商，所以它的最大值为 μ_1，且只在满足 $\boldsymbol{S}\boldsymbol{x} = \mu_1 \boldsymbol{B}\boldsymbol{x}$ 与 $\boldsymbol{x}^{\top}\boldsymbol{B}\boldsymbol{x} = 1$ 的 $\boldsymbol{x}$ 处取到。 ■

上面只用到 $\boldsymbol{C}$ 两端的特征向量。对 $\boldsymbol{C}$ 应用完整的谱分解，还能得到全部广义特征向量的结构：它们可以选得关于加权内积 $\langle \cdot, \cdot \rangle_{\boldsymbol{B}}$ 互相正交。

定理 15.16　$\boldsymbol{B}$ 正交的广义特征向量　设 $\boldsymbol{S}$ 对称、$\boldsymbol{B}$ 对称正定，广义特征值为 $\mu_1 \geq \cdots \geq \mu_d$。则存在 $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_d$，使

$$\boldsymbol{S}\boldsymbol{v}_i = \mu_i \boldsymbol{B}\boldsymbol{v}_i, \qquad \boldsymbol{v}_i^{\top}\boldsymbol{B}\boldsymbol{v}_j = \delta_{i,j} \quad (i, j = 1, \ldots, d).$$

记 $\boldsymbol{V} = [\boldsymbol{v}_1, \ldots, \boldsymbol{v}_d]$，$\boldsymbol{M} = \operatorname{diag}(\mu_1, \ldots, \mu_d)$，上式等价于 $\boldsymbol{V}^{\top}\boldsymbol{B}\boldsymbol{V} = \boldsymbol{I}$ 与 $\boldsymbol{V}^{\top}\boldsymbol{S}\boldsymbol{V} = \boldsymbol{M}$。

证明　由谱定理，$\boldsymbol{C} = \boldsymbol{Z}\boldsymbol{M}\boldsymbol{Z}^{\top}$，其中 $\boldsymbol{Z} = [\boldsymbol{z}_1, \ldots, \boldsymbol{z}_d]$ 为正交矩阵，$\boldsymbol{C}\boldsymbol{z}_i = \mu_i \boldsymbol{z}_i$。令 $\boldsymbol{V} = \boldsymbol{L}^{-1}\boldsymbol{Z}$，即 $\boldsymbol{v}_i = \boldsymbol{L}^{-1}\boldsymbol{z}_i$。由上面的一一对应，$\boldsymbol{S}\boldsymbol{v}_i = \mu_i \boldsymbol{B}\boldsymbol{v}_i$。又

$$\boldsymbol{V}^{\top}\boldsymbol{B}\boldsymbol{V} = \boldsymbol{Z}^{\top}\boldsymbol{L}^{-\top}\boldsymbol{L}^{\top}\boldsymbol{L}\boldsymbol{L}^{-1}\boldsymbol{Z} = \boldsymbol{Z}^{\top}\boldsymbol{Z} = \boldsymbol{I},$$
$$\boldsymbol{V}^{\top}\boldsymbol{S}\boldsymbol{V} = \boldsymbol{Z}^{\top}\boldsymbol{L}^{-\top}\boldsymbol{S}\boldsymbol{L}^{-1}\boldsymbol{Z} = \boldsymbol{Z}^{\top}\boldsymbol{C}\boldsymbol{Z} = \boldsymbol{M}.$$

逐元素比较第一式即得 $\boldsymbol{v}_i^{\top}\boldsymbol{B}\boldsymbol{v}_j = \delta_{i,j}$。 ■

$\boldsymbol{V}$ 可逆，所以任意 $\boldsymbol{x}$ 都能写成 $\boldsymbol{x}=\sum_i a_i\boldsymbol{v}_i$。由定理，$\boldsymbol{x}^{\top}\boldsymbol{B}\boldsymbol{x}=\sum_i a_i^2$，$\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}=\sum_i \mu_i a_i^2$，广义 Rayleigh 商再次成为特征值的加权平均，这与普通情形完全平行，只是坐标改成了 $\boldsymbol{B}$ 正交的广义特征向量。

至此两端极值都已求出。若还需要刻画中间的广义特征值，可以对 $\boldsymbol{C}$ 使用第 7.2.1节的 Courant–Fischer 最小最大原理（定理 7.11），再按 $\boldsymbol{z}=\boldsymbol{L}\boldsymbol{x}$ 换回原坐标。

算法实现与算例 先回到开头的二维例子，按化归的步骤算出最优方向，并核验它们确实满足约束与广义特征方程。

示例 15.17 加权约束下的最优方向 取 $\boldsymbol{S}=\operatorname{diag}(4,1)$ 与 $\boldsymbol{B}=\operatorname{diag}(9,1)$，在加权约束 $\boldsymbol{x}^{\top}\boldsymbol{B}\boldsymbol{x}=1$ 下求 $\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}$ 的最大值、最小值与最优方向。

先化归为普通 Rayleigh 商。取 $\boldsymbol{L}=\operatorname{diag}(3,1)$，则 $\boldsymbol{L}^{\top}\boldsymbol{L}=\boldsymbol{B}$，

$$\boldsymbol{C}=\boldsymbol{L}^{-\top}\boldsymbol{S}\boldsymbol{L}^{-1}=\operatorname{diag}\Big(\frac{4}{9},1\Big).$$

由定理 15.4，$R_{\boldsymbol{C}}$ 的最大值为 1，在 $\boldsymbol{z}=\pm\boldsymbol{e}_2$ 取到；最小值为 $4/9$，在 $\boldsymbol{z}=\pm\boldsymbol{e}_1$ 取到。换回原坐标 $\boldsymbol{v}=\boldsymbol{L}^{-1}\boldsymbol{z}$，最大方向为 $\pm\boldsymbol{e}_2$，最小方向为 $\pm\boldsymbol{e}_1/3$。

再核验这两个向量满足约束与广义特征方程。由

$$\boldsymbol{e}_2^{\top}\boldsymbol{B}\boldsymbol{e}_2=1,\qquad \Big(\frac{\boldsymbol{e}_1}{3}\Big)^{\top}\boldsymbol{B}\,\frac{\boldsymbol{e}_1}{3}=\frac{9}{9}=1,$$

两者都满足加权单位约束。又 $\boldsymbol{S}\boldsymbol{e}_2=\boldsymbol{e}_2=1\cdot\boldsymbol{B}\boldsymbol{e}_2$，而

$$\boldsymbol{S}\frac{\boldsymbol{e}_1}{3}=\frac{4}{3}\boldsymbol{e}_1=\frac{4}{9}\cdot\boldsymbol{B}\frac{\boldsymbol{e}_1}{3},$$

所以它们分别是属于 1 与 $4/9$ 的广义特征向量，且 $\boldsymbol{e}_2^{\top}\boldsymbol{B}(\boldsymbol{e}_1/3)=0$，满足 $\boldsymbol{B}$ 正交。

最后不经化归，直接比较全部可行方向。约束给出 $x_2^2=1-9x_1^2$，其中 $x_1^2\in[0,1/9]$，于是

$$\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}=4x_1^2+1-9x_1^2=1-5x_1^2\in\Big[\frac{4}{9},1\Big].$$

最大值 1 在 $x_1=0$ 即 $\pm\boldsymbol{e}_2$ 处取到，最小值 $4/9$ 在 $x_1^2=1/9$ 即 $\pm\boldsymbol{e}_1/3$ 处取到，与化归的结果一致。对照示例 15.5：同一个 $\boldsymbol{S}$ 在欧氏约束下的最大方向是 $\boldsymbol{e}_1$，加权约束让沿 $\boldsymbol{e}_1$ 的可行向量缩短为 $\boldsymbol{e}_1/3$，最大方向就换成了 $\boldsymbol{e}_2$。

上面的例子中 $\boldsymbol{L}$ 是对角矩阵，可以直接求逆。一般情形下，计算也按化归的步骤进行，但通过因子分解与线性求解完成换元，不必显式形成 $\boldsymbol{L}^{-1}$。

第一步，用第 10章的 Cholesky 分解求出 $\boldsymbol{B}$ 的三角因子，把 $\boldsymbol{L}$ 取成上三角矩阵；若分解失败，说明 $\boldsymbol{B}$ 不是正定矩阵，正定化归不能继续使用。第二步，分两次三角求解形成 $\boldsymbol{C}$：先解 $\boldsymbol{L}^{\top}\boldsymbol{W}=\boldsymbol{S}$，得到 $\boldsymbol{W}=\boldsymbol{L}^{-\top}\boldsymbol{S}$；再解 $\boldsymbol{L}^{\top}\boldsymbol{C}^{\top}=\boldsymbol{W}^{\top}$，得到 $\boldsymbol{C}=\boldsymbol{W}\boldsymbol{L}^{-1}$。

第三步，对对称矩阵 $\boldsymbol{C}$ 作正交谱分解，按所求的是最大值还是最小值取单位特征向量 $\boldsymbol{z}$。第四步，解三角方程组 $\boldsymbol{L}\boldsymbol{v}=\boldsymbol{z}$ 换回原坐标；由 $\boldsymbol{v}^{\top}\boldsymbol{B}\boldsymbol{v}=\boldsymbol{z}^{\top}\boldsymbol{z}=1$，所得 $\boldsymbol{v}$ 自动满足加权单位约束。最后核验广义特征残差 $\boldsymbol{S}\boldsymbol{v}-\mu\boldsymbol{B}\boldsymbol{v}$ 与加权长度 $\boldsymbol{v}^{\top}\boldsymbol{B}\boldsymbol{v}$。整个过程保持对称结构，只需对称矩阵的特征值算法。

示例 15.18　按三角求解的步骤计算　取 $\boldsymbol{S}=\operatorname{diag}(2,3)$、$\boldsymbol{B}=\operatorname{diag}(4,1)$。$\boldsymbol{B}$ 的 Cholesky 因子为 $\boldsymbol{L}=\operatorname{diag}(2,1)$。解 $\boldsymbol{L}^{\top}\boldsymbol{W}=\boldsymbol{S}$ 得 $\boldsymbol{W}=\operatorname{diag}(1,3)$，再由 $\boldsymbol{C}=\boldsymbol{W}\boldsymbol{L}^{-1}$ 得 $\boldsymbol{C}=\operatorname{diag}(1/2,3)$。

$\boldsymbol{C}$ 的最大特征值 3 对应 $\boldsymbol{z}=\boldsymbol{e}_2$，解 $\boldsymbol{L}\boldsymbol{v}=\boldsymbol{z}$ 得 $\boldsymbol{v}=(0,1)^{\top}$；最小特征值 $1/2$ 对应 $\boldsymbol{z}=\boldsymbol{e}_1$，得 $\boldsymbol{v}=(1/2,0)^{\top}$。核验：$\boldsymbol{S}(0,1)^{\top}=(0,3)^{\top}=3\boldsymbol{B}(0,1)^{\top}$，$\boldsymbol{S}(1/2,0)^{\top}=(1,0)^{\top}=\frac{1}{2}\cdot(2,0)^{\top}=\frac{1}{2}\boldsymbol{B}(1/2,0)^{\top}$，且 $(1/2)^2\cdot 4=1$。所以加权约束下的最大值为 3、最小值为 $1/2$。

与欧氏约束比较：$\boldsymbol{S}$ 的普通 Rayleigh 商最大为 3、最小为 2，最优直线同样是两条坐标轴。这里加权没有改变最优直线，却把最小值由 2 变成 $1/2$，因为沿 $\boldsymbol{e}_1$ 满足加权约束的向量缩短为 $\boldsymbol{e}_1/2$。与示例 15.17合起来看，长度标准既可能改变最优方向，也可能只改变最优值。

算法分析　形成 $\boldsymbol{C}$ 只用到 Cholesky 分解与以三角矩阵为系数的求解，代价都是 $O(d^3)$ 次运算；之后的主要代价在对称特征值计算，所用算法本书不作分析。只需要最大或最小的广义特征对时，也必须先完成同样的换元，因为 $\boldsymbol{S}$ 本身的特征向量一般不是广义特征向量。

另一种看似直接的做法是把 $\boldsymbol{S}\boldsymbol{v}=\mu\boldsymbol{B}\boldsymbol{v}$ 左乘 $\boldsymbol{B}^{-1}$，改求普通特征问题 $\boldsymbol{B}^{-1}\boldsymbol{S}\boldsymbol{v}=\mu\boldsymbol{v}$。由 $\boldsymbol{B}^{-1}\boldsymbol{S}=\boldsymbol{L}^{-1}\boldsymbol{L}^{-\top}\boldsymbol{S}=\boldsymbol{L}^{-1}\boldsymbol{C}\boldsymbol{L}$，它与 $\boldsymbol{C}$ 相似，特征值相同；但 $\boldsymbol{B}^{-1}\boldsymbol{S}$ 一般不对称。

例如 $\boldsymbol{S}=\left[\begin{smallmatrix}2&1\\1&2\end{smallmatrix}\right]$、$\boldsymbol{B}=\operatorname{diag}(2,1)$ 时，$\boldsymbol{B}^{-1}\boldsymbol{S}=\left[\begin{smallmatrix}1&1/2\\1&2\end{smallmatrix}\right]$。它的特征多项式为 $z^2-3z+\frac{3}{2}$，特征值为 $\mu_{1,2}=(3\pm\sqrt{3})/2$；由第一行 $(1-\mu)x_1+\frac{1}{2}x_2=0$ 得特征向量 $\boldsymbol{v}_1=(1,1+\sqrt{3})^{\top}$、$\boldsymbol{v}_2=(1,1-\sqrt{3})^{\top}$。这两个向量就是广义特征向量，满足 $\boldsymbol{v}_1^{\top}\boldsymbol{B}\boldsymbol{v}_2=2+(1-3)=0$，关于 $\boldsymbol{B}$ 正交；但 $\boldsymbol{v}_1^{\top}\boldsymbol{v}_2=1+(1-3)=-1\neq 0$，

在欧氏内积下并不正交。所以不能对 $\boldsymbol{B}^{-1}\boldsymbol{S}$ 套用谱定理与欧氏正交特征基的结论。前面两个二维例子里 $\boldsymbol{B}^{-1}\boldsymbol{S}$ 恰好是对角矩阵，只是特殊情形。

本小节的化归依赖 $\boldsymbol{B}$ 正定。若 $\boldsymbol{B}$ 不是正定矩阵，$\boldsymbol{x}^{\top}\boldsymbol{B}\boldsymbol{x}$ 不再定义长度：$\boldsymbol{B}$ 半正定而奇异时，存在 $\boldsymbol{x}\neq\boldsymbol{0}$ 使分母为零；$\boldsymbol{B}$ 不定时，$\boldsymbol{x}^{\top}\boldsymbol{B}\boldsymbol{x}$ 可以为负。这时也不存在可逆的 $\boldsymbol{L}$ 使 $\boldsymbol{B}=\boldsymbol{L}^{\top}\boldsymbol{L}$：若有这样的 $\boldsymbol{L}$，则 $\boldsymbol{x}\neq\boldsymbol{0}$ 时 $\boldsymbol{L}\boldsymbol{x}\neq\boldsymbol{0}$，$\boldsymbol{x}^{\top}\boldsymbol{B}\boldsymbol{x}=\|\boldsymbol{L}\boldsymbol{x}\|_2^2>0$，$\boldsymbol{B}$ 就是正定的。

于是化归无从进行，约束问题甚至可能没有极值。例如 $\boldsymbol{S}=\boldsymbol{I}$、$\boldsymbol{B}=\operatorname{diag}(1,0)$ 时，约束 $x_1^2=1$ 不限制 x_2，而 $\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}=1+x_2^2$ 没有上界。这类更一般的广义特征问题不在此展开。

15.4.2 加权低秩逼近

主要思想 现在改变重建误差的度量。设 $\boldsymbol{A}\in\mathbb{R}^{m\times d}$ 的各行表示不同的量，重要性或单位不同；各列表示不同的样本，可信程度也不同。给定对称正定的行权重 $\boldsymbol{\Omega}_{\mathrm{r}}\in\mathbb{R}^{m\times m}$ 与列权重 $\boldsymbol{\Omega}_{\mathrm{c}}\in\mathbb{R}^{d\times d}$，用

$$E(\boldsymbol{X})=\operatorname{tr}\big((\boldsymbol{A}-\boldsymbol{X})^{\top}\boldsymbol{\Omega}_{\mathrm{r}}(\boldsymbol{A}-\boldsymbol{X})\boldsymbol{\Omega}_{\mathrm{c}}\big)$$

度量 $\boldsymbol{X}$ 的误差，并在 $\operatorname{rank}\boldsymbol{X}\le k$ 下求其最小值，称为**加权低秩逼近**（weighted low-rank approximation）。$\boldsymbol{\Omega}_{\mathrm{r}}=\boldsymbol{I}$、$\boldsymbol{\Omega}_{\mathrm{c}}=\boldsymbol{I}$ 时它就是上一节的 Frobenius 平方误差。

两个权重都是对角矩阵时，记 $\boldsymbol{\Omega}_{\mathrm{r}}=\operatorname{diag}(\omega_1,\dots,\omega_m)$、$\boldsymbol{\Omega}_{\mathrm{c}}=\operatorname{diag}(\tau_1,\dots,\tau_d)$，展开迹得

$$E(\boldsymbol{X})=\sum_{i=1}^{m}\sum_{j=1}^{d}\omega_i\tau_j(a_{i,j}-x_{i,j})^2,$$

即第 (i,j) 个元素的平方偏差乘以权重 $\omega_i\tau_j$。所以这一类误差包含逐元素加权，但要求权重能分离成行因子与列因子的乘积。

为了化归，取 Gram 因子。由定理 3.52，存在可逆的 $\boldsymbol{K}$ 与 $\boldsymbol{N}$，使 $\boldsymbol{\Omega}_{\mathrm{r}}=\boldsymbol{K}^{\top}\boldsymbol{K}$、$\boldsymbol{\Omega}_{\mathrm{c}}=\boldsymbol{N}\boldsymbol{N}^{\top}$（对 $\boldsymbol{\Omega}_{\mathrm{c}}$ 取 $\boldsymbol{N}^{\top}$ 为它的 Gram 因子）。记 $\boldsymbol{M}=\boldsymbol{A}-\boldsymbol{X}$，由迹的循环性，

$$\|\boldsymbol{K}\boldsymbol{M}\boldsymbol{N}\|_{\mathrm{F}}^2=\operatorname{tr}(\boldsymbol{N}^{\top}\boldsymbol{M}^{\top}\boldsymbol{K}^{\top}\boldsymbol{K}\boldsymbol{M}\boldsymbol{N})=\operatorname{tr}(\boldsymbol{M}^{\top}\boldsymbol{\Omega}_{\mathrm{r}}\boldsymbol{M}\boldsymbol{N}\boldsymbol{N}^{\top})=E(\boldsymbol{X}).$$

于是 $E(\boldsymbol{X})=\|\boldsymbol{K}(\boldsymbol{A}-\boldsymbol{X})\boldsymbol{N}\|_{\mathrm{F}}^2$：加权误差是变换后矩阵的普通 Frobenius 误差。

令 $\widetilde{\boldsymbol{A}}=\boldsymbol{K}\boldsymbol{A}\boldsymbol{N}$、$\boldsymbol{Z}=\boldsymbol{K}\boldsymbol{X}\boldsymbol{N}$，则 $E(\boldsymbol{X})=\|\widetilde{\boldsymbol{A}}-\boldsymbol{Z}\|_{\mathrm{F}}^2$。秩约束在这个变换下不变：乘积的列空间含于左因子的列空间，所以 $\operatorname{rank}\boldsymbol{Z}\le\operatorname{rank}\boldsymbol{X}$；又 $\boldsymbol{X}=\boldsymbol{K}^{-1}\boldsymbol{Z}\boldsymbol{N}^{-1}$，同理 $\operatorname{rank}\boldsymbol{X}\le\operatorname{rank}\boldsymbol{Z}$，故二者相等。

于是 $\boldsymbol{X} \mapsto \boldsymbol{K}\boldsymbol{X}\boldsymbol{N}$ 把秩不超过 k 的矩阵一一地变为秩不超过 k 的矩阵，原问题等价于对 $\widetilde{\boldsymbol{A}}$ 作普通的低秩逼近。由定理 15.11与定理 15.12立即得到下面的结论。

定理 15.19　可分离权重下的最佳低秩逼近　设 $\boldsymbol{\Omega}_{\mathrm{r}} = \boldsymbol{K}^{\top}\boldsymbol{K}$、$\boldsymbol{\Omega}_{\mathrm{c}} = \boldsymbol{N}\boldsymbol{N}^{\top}$，$\boldsymbol{K}$、$\boldsymbol{N}$ 可逆，$\widetilde{\boldsymbol{A}} = \boldsymbol{K}\boldsymbol{A}\boldsymbol{N}$ 的奇异值为 $\tilde{\sigma}_1 \geq \cdots \geq \tilde{\sigma}_r > 0$，其中 $r = \operatorname{rank}\widetilde{\boldsymbol{A}} = \operatorname{rank}\boldsymbol{A}$。对 $0 \leq k < r$，

$$\min_{\operatorname{rank}\boldsymbol{X} \leq k} E(\boldsymbol{X}) = \sum_{i=k+1}^{r} \tilde{\sigma}_i^2,$$

最小值由 $\boldsymbol{X}_k = \boldsymbol{K}^{-1}\widetilde{\boldsymbol{A}}_k\boldsymbol{N}^{-1}$ 达到，其中 $\widetilde{\boldsymbol{A}}_k$ 是 $\widetilde{\boldsymbol{A}}$ 的截断 SVD。若 $1 \leq k < r$ 且 $\tilde{\sigma}_k > \tilde{\sigma}_{k+1}$，最优解唯一。

证明　由上面的等式，$E(\boldsymbol{X}) = \|\widetilde{\boldsymbol{A}} - \boldsymbol{K}\boldsymbol{X}\boldsymbol{N}\|_{\mathrm{F}}^2$，而 $\boldsymbol{X} \mapsto \boldsymbol{K}\boldsymbol{X}\boldsymbol{N}$ 是秩不超过 k 的矩阵集合到自身的一一映射。所以 E 在原集合上的最小值等于 $\|\widetilde{\boldsymbol{A}} - \boldsymbol{Z}\|_{\mathrm{F}}^2$ 在 $\operatorname{rank}\boldsymbol{Z} \leq k$ 上的最小值，由定理 15.11，它等于 $\sum_{i>k}\tilde{\sigma}_i^2$，在 $\boldsymbol{Z} = \widetilde{\boldsymbol{A}}_k$ 即 $\boldsymbol{X} = \boldsymbol{X}_k$ 处取到。有间隙时，由定理 15.12，最优的 $\boldsymbol{Z}$ 唯一，一一映射保证最优的 $\boldsymbol{X}$ 也唯一。 ■

最优解的结构可以用上一小节的广义 Rayleigh 商看清。只设行权重，取 $\boldsymbol{\Omega}_{\mathrm{c}} = \boldsymbol{I}$、$\boldsymbol{N} = \boldsymbol{I}$，并取 $k = 1$。变换后的秩一候选写成 $\boldsymbol{Z} = \boldsymbol{z}\boldsymbol{c}^{\top}$，$\|\boldsymbol{z}\|_2 = 1$；令 $\boldsymbol{w} = \boldsymbol{K}^{-1}\boldsymbol{z}$，则原坐标中的候选是 $\boldsymbol{X} = \boldsymbol{w}\boldsymbol{c}^{\top}$，单位约束变为 $\boldsymbol{w}^{\top}\boldsymbol{\Omega}_{\mathrm{r}}\boldsymbol{w} = \boldsymbol{z}^{\top}\boldsymbol{z} = 1$。

按第 15.2节，变换后问题的保留量是

$$\boldsymbol{z}^{\top}\widetilde{\boldsymbol{A}}\widetilde{\boldsymbol{A}}^{\top}\boldsymbol{z} = \boldsymbol{w}^{\top}\boldsymbol{K}^{\top}\boldsymbol{K}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{K}^{\top}\boldsymbol{K}\boldsymbol{w} = \boldsymbol{w}^{\top}\boldsymbol{\Omega}_{\mathrm{r}}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{\Omega}_{\mathrm{r}}\boldsymbol{w}.$$

所以最佳方向 $\boldsymbol{w}$ 使广义 Rayleigh 商 $R_{\boldsymbol{\Omega}_{\mathrm{r}}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{\Omega}_{\mathrm{r}},\boldsymbol{\Omega}_{\mathrm{r}}}$ 取最大值，是广义特征问题 $\boldsymbol{\Omega}_{\mathrm{r}}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{\Omega}_{\mathrm{r}}\boldsymbol{w} = \mu\boldsymbol{\Omega}_{\mathrm{r}}\boldsymbol{w}$ 的最大特征向量。按本节的化归，这里的 $\boldsymbol{C} = \boldsymbol{K}^{-\top}(\boldsymbol{\Omega}_{\mathrm{r}}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{\Omega}_{\mathrm{r}})\boldsymbol{K}^{-1} = \widetilde{\boldsymbol{A}}\widetilde{\boldsymbol{A}}^{\top}$，最大广义特征值就是 $\tilde{\sigma}_1^2$。

对应的最优系数是 $\boldsymbol{c} = \widetilde{\boldsymbol{A}}^{\top}\boldsymbol{z} = \boldsymbol{A}^{\top}\boldsymbol{\Omega}_{\mathrm{r}}\boldsymbol{w}$，最优近似为 $\boldsymbol{X}_1 = \boldsymbol{w}\boldsymbol{w}^{\top}\boldsymbol{\Omega}_{\mathrm{r}}\boldsymbol{A}$。矩阵 $\boldsymbol{w}\boldsymbol{w}^{\top}\boldsymbol{\Omega}_{\mathrm{r}}$ 满足 $(\boldsymbol{w}\boldsymbol{w}^{\top}\boldsymbol{\Omega}_{\mathrm{r}})^2 = \boldsymbol{w}\boldsymbol{w}^{\top}\boldsymbol{\Omega}_{\mathrm{r}}$，且 $\boldsymbol{\Omega}_{\mathrm{r}}\boldsymbol{w}\boldsymbol{w}^{\top}\boldsymbol{\Omega}_{\mathrm{r}}$ 对称，它是关于加权内积 $\langle\cdot,\cdot\rangle_{\boldsymbol{\Omega}_{\mathrm{r}}}$ 到 $\operatorname{span}\{\boldsymbol{w}\}$ 的正交投影。所以加权秩一逼近与第 15.2节完全平行，只是长度与投影都换成了按 $\boldsymbol{\Omega}_{\mathrm{r}}$ 度量。

权重改变了用于排序的奇异方向：决定保留哪些方向的是 $\widetilde{\boldsymbol{A}}$ 的奇异值，而不是 $\boldsymbol{A}$ 的。因此直接截断原矩阵 $\boldsymbol{A}$，一般不再是加权意义下的最优解，下面的例子给出具体比较。

这一化归要求误差能写成左右乘法的形式，任意的逐元素权重未必满足。若对一切 $\boldsymbol{X}$ 都有 $E(\boldsymbol{X})=\sum_{i,j} w_{i,j}(a_{i,j}-x_{i,j})^2$，取 $\boldsymbol{A}-\boldsymbol{X}=\boldsymbol{e}_i\boldsymbol{e}_j^{\top}$，左端为 $(\boldsymbol{\Omega}_{\mathrm{r}})_{i,i}(\boldsymbol{\Omega}_{\mathrm{c}})_{j,j}$，右端为 $w_{i,j}$，于是权重矩阵必是行因子与列因子的乘积，$w_{i,j}w_{k,l}=w_{i,l}w_{k,j}$。例如 $\left[\begin{smallmatrix}1&2\\2&1\end{smallmatrix}\right]$ 不满足 $1\cdot 1=2\cdot 2$，不能这样化归；缺失元素对应权重为零，也不满足正定性要求。

这些情形下误差不再按任何正交投影分解，没有截断 SVD 式的闭式解，一般只能用迭代优化求解，并且要分别讨论所得解是否为全局最优。这类问题的通用求解方法由卷五展开，可参考卷五第 1 章“优化问题与解”。

算法实现与算例　计算按化归的顺序进行。第一步，对 $\boldsymbol{\Omega}_{\mathrm{r}}$ 与 $\boldsymbol{\Omega}_{\mathrm{c}}$ 作 Cholesky 分解得到三角因子 $\boldsymbol{K}$、$\boldsymbol{N}$；权重是对角矩阵时直接取各对角元的平方根。第二步，形成 $\widetilde{\boldsymbol{A}}=\boldsymbol{K}\boldsymbol{A}\boldsymbol{N}$，求它的 SVD 并截断，得到 $\widetilde{\boldsymbol{A}}_k$。

第三步，还原 $\boldsymbol{X}_k=\boldsymbol{K}^{-1}\widetilde{\boldsymbol{A}}_k\boldsymbol{N}^{-1}$：先解 $\boldsymbol{Y}\boldsymbol{N}=\widetilde{\boldsymbol{A}}_k$，即 $\boldsymbol{N}^{\top}\boldsymbol{Y}^{\top}=\widetilde{\boldsymbol{A}}_k^{\top}$，再解 $\boldsymbol{K}\boldsymbol{X}_k=\boldsymbol{Y}$，用两次三角求解代替显式求逆。若只需要低秩因子，可以只对 $\widetilde{\boldsymbol{U}}_k$ 与 $\widetilde{\boldsymbol{V}}_k^{\top}$ 分别作这两次求解，得到 $\boldsymbol{X}_k=(\boldsymbol{K}^{-1}\widetilde{\boldsymbol{U}}_k)\widetilde{\boldsymbol{\Sigma}}_k(\widetilde{\boldsymbol{V}}_k^{\top}\boldsymbol{N}^{-1})$，秩不超过 k 由因子形式直接保证。最后在原坐标下核验秩与加权残差 $E(\boldsymbol{X}_k)=\sum_{i>k}\tilde{\sigma}_i^2$。

示例 15.20　行加权改变保留的方向　取 $\boldsymbol{A}=\operatorname{diag}(3,2)$，行权重 $\boldsymbol{\Omega}_{\mathrm{r}}=\operatorname{diag}(1,4)$，列权重 $\boldsymbol{\Omega}_{\mathrm{c}}=\boldsymbol{I}$，$k=1$。取 $\boldsymbol{K}=\operatorname{diag}(1,2)$、$\boldsymbol{N}=\boldsymbol{I}$，变换后为 $\widetilde{\boldsymbol{A}}=\operatorname{diag}(3,4)$，奇异值为 4（方向 $\boldsymbol{e}_2$）与 3（方向 $\boldsymbol{e}_1$）。

保留第二方向得 $\widetilde{\boldsymbol{A}}_1=\operatorname{diag}(0,4)$，还原为 $\boldsymbol{X}_1=\boldsymbol{K}^{-1}\widetilde{\boldsymbol{A}}_1=\operatorname{diag}(0,2)$。它的加权误差是 $\|\boldsymbol{K}(\boldsymbol{A}-\boldsymbol{X}_1)\|_{\mathrm{F}}=\|\operatorname{diag}(3,0)\|_{\mathrm{F}}=3=\tilde{\sigma}_2$。直接截断 $\boldsymbol{A}$ 得到 $\operatorname{diag}(3,0)$，加权误差为 $\|\boldsymbol{K}\operatorname{diag}(0,2)\|_{\mathrm{F}}=\|\operatorname{diag}(0,4)\|_{\mathrm{F}}=4$，更大。

用广义 Rayleigh 商核对：$\boldsymbol{\Omega}_{\mathrm{r}}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{\Omega}_{\mathrm{r}}=\operatorname{diag}(9,64)$，关于 $\boldsymbol{\Omega}_{\mathrm{r}}=\operatorname{diag}(1,4)$ 的广义特征值为 9 与 16。最大者 $16=\tilde{\sigma}_1^2$ 对应 $\boldsymbol{w}=\boldsymbol{e}_2/2$（满足 $\boldsymbol{w}^{\top}\boldsymbol{\Omega}_{\mathrm{r}}\boldsymbol{w}=1$），系数 $\boldsymbol{c}=\boldsymbol{A}^{\top}\boldsymbol{\Omega}_{\mathrm{r}}\boldsymbol{w}=(0,4)^{\top}$，重建 $\boldsymbol{w}\boldsymbol{c}^{\top}=\operatorname{diag}(0,2)=\boldsymbol{X}_1$。第二行的权重放大了它的偏差，所以虽然 $\boldsymbol{A}$ 的第一列更长，最优近似却保留了第二个坐标方向。

算法分析　除一次 $m\times d$ 矩阵的 SVD 外，其余步骤是两次 Cholesky 分解、两次矩阵乘法与若干三角求解，代价为 $O(m^3+d^3+md(m+d))$ 次运算。权重必须正定；某行或某列权重为零时，相应的 $\boldsymbol{K}$ 或 $\boldsymbol{N}$ 不可逆，还原步骤无法进行。

还原步骤还会放大计算误差。若 $\widetilde{\boldsymbol{A}}_k$ 带有误差 $\boldsymbol{\Delta}$，还原后的误差为 $\boldsymbol{K}^{-1}\boldsymbol{\Delta}\boldsymbol{N}^{-1}$；逐列、逐行应用谱范数的定义，可得 $\|\boldsymbol{K}^{-1}\boldsymbol{\Delta}\boldsymbol{N}^{-1}\|_{\mathrm{F}}\le$

$\|\boldsymbol{K}^{-1}\|_2\|\boldsymbol{\Delta}\|_{\mathrm{F}}\|\boldsymbol{N}^{-1}\|_2$。权重的最大、最小特征值相差悬殊时，这个放大倍数可能很大，原坐标下的结果需要按第 15.6节的方法核验。

15.5 正交约束下的矩阵逼近

前面的约束是秩预算，本节把约束换成正交性。给定方阵 $\boldsymbol{A}\in\mathbb{R}^{d\times d}$，在全部正交矩阵 $\boldsymbol{R}$（$\boldsymbol{R}^{\top}\boldsymbol{R}=\boldsymbol{I}$）中寻找离 $\boldsymbol{A}$ 最近的一个，误差仍用 Frobenius 范数。正交矩阵保持长度，所以问题是：哪一个保长作用最接近给定的线性作用？例如测得的旋转因噪声不再正交时，就要把它修正为最近的正交矩阵。

正交矩阵组成的集合不是线性子空间，也不由秩描述，前两节的投影化归不能沿用。第 6章已经构造了极分解 $\boldsymbol{A}=\boldsymbol{W}\boldsymbol{H}$ 的正交因子 $\boldsymbol{W}$；本节证明它正是所求的最近正交矩阵，再讨论要求 $\det\boldsymbol{R}=1$ 时答案怎样改变。

15.5.1 正交逼近的最优解

主要思想 先把距离化为一个更简单的目标。对任意正交矩阵 $\boldsymbol{R}$，由 $\|\boldsymbol{R}\|_{\mathrm{F}}^2=\operatorname{tr}(\boldsymbol{R}^{\top}\boldsymbol{R})=\operatorname{tr}\boldsymbol{I}=d$，

$$\|\boldsymbol{A}-\boldsymbol{R}\|_{\mathrm{F}}^2=\|\boldsymbol{A}\|_{\mathrm{F}}^2+d-2\operatorname{tr}(\boldsymbol{R}^{\top}\boldsymbol{A}),$$

前两项与 $\boldsymbol{R}$ 无关，所以距离最小等价于在正交矩阵中最大化 $\operatorname{tr}(\boldsymbol{R}^{\top}\boldsymbol{A})$。这个目标关于 $\boldsymbol{R}$ 是线性的；第 15.3.1节选择子空间时的 $\operatorname{tr}(\boldsymbol{Y}^{\top}\boldsymbol{G}\boldsymbol{Y})$ 关于 $\boldsymbol{Y}$ 是二次的，那里的迹极值界不能直接搬用，需要重新给出上界。

上界来自 SVD。代入 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$，令 $\boldsymbol{Z}=\boldsymbol{U}^{\top}\boldsymbol{R}\boldsymbol{V}$。它是正交矩阵的乘积，仍然正交，且 $\boldsymbol{R}=\boldsymbol{U}\boldsymbol{Z}\boldsymbol{V}^{\top}$；$\boldsymbol{R}$ 取遍全部正交矩阵时，$\boldsymbol{Z}$ 也取遍全部正交矩阵。于是问题变成在正交矩阵 $\boldsymbol{Z}$ 中最大化 $\operatorname{tr}(\boldsymbol{Z}^{\top}\boldsymbol{\Sigma})=\sum_i\sigma_i z_{i,i}$。

定理 15.21 最佳正交逼近 设 $\boldsymbol{A}\in\mathbb{R}^{d\times d}$ 有 SVD$\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$。对任意正交矩阵 $\boldsymbol{R}$，

$$\operatorname{tr}(\boldsymbol{R}^{\top}\boldsymbol{A})\le\sum_{i=1}^{d}\sigma_i,$$

取 $\boldsymbol{R}=\boldsymbol{U}\boldsymbol{V}^{\top}$ 时等号成立。因此

$$\min_{\boldsymbol{R}^{\top}\boldsymbol{R}=\boldsymbol{I}}\|\boldsymbol{A}-\boldsymbol{R}\|_{\mathrm{F}}^2=\sum_{i=1}^{d}(\sigma_i-1)^2,$$

最小值由极分解的正交因子达到。$\boldsymbol{A}$ 可逆时最优解唯一，就是 $\boldsymbol{W}=\boldsymbol{A}(\boldsymbol{A}^{\top}\boldsymbol{A})^{-1/2}$。

证明 令 $\boldsymbol{Z} = \boldsymbol{U}^{\top}\boldsymbol{R}\boldsymbol{V}$。由迹的循环性，

$$\operatorname{tr}(\boldsymbol{R}^{\top}\boldsymbol{A}) = \operatorname{tr}(\boldsymbol{V}\boldsymbol{Z}^{\top}\boldsymbol{U}^{\top}\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}) = \operatorname{tr}(\boldsymbol{Z}^{\top}\boldsymbol{\Sigma}) = \sum_{i=1}^{d}\sigma_i z_{i,i}.$$

$\boldsymbol{Z}$ 的每一列都是单位向量，所以 $|z_{i,i}| \le 1$；又 $\sigma_i \ge 0$，故 $\sigma_i z_{i,i} \le \sigma_i$，求和即得上界。$\boldsymbol{R} = \boldsymbol{U}\boldsymbol{V}^{\top}$ 时 $\boldsymbol{Z} = \boldsymbol{I}$，等号成立。

由式 (5.6)，$\|\boldsymbol{A}\|_{\mathrm{F}}^2 = \sum_i \sigma_i^2$，代入展开式得最小值

$$\sum_{i=1}^{d}\sigma_i^2 + d - 2\sum_{i=1}^{d}\sigma_i = \sum_{i=1}^{d}(\sigma_i - 1)^2.$$

由定理 6.5，$\boldsymbol{U}\boldsymbol{V}^{\top}$ 是极分解的正交因子。

设 $\boldsymbol{A}$ 可逆，则全部 $\sigma_i > 0$。等号要求每一项 $\sigma_i z_{i,i} = \sigma_i$，即 $z_{i,i} = 1$；单位列向量 $\boldsymbol{Z}_{:,i}$ 的第 i 个分量为 1，其余分量只能为零，于是 $\boldsymbol{Z}_{:,i} = \boldsymbol{e}_i$，$\boldsymbol{Z} = \boldsymbol{I}$，$\boldsymbol{R} = \boldsymbol{U}\boldsymbol{V}^{\top}$。由定理 6.3，它就是 $\boldsymbol{W}$。 ■

去掉伸缩得到的正交因子，同时解决了“离 $\boldsymbol{A}$ 最近的正交矩阵”这个问题；这一结论称为**最佳正交逼近**（best orthogonal approximation）。误差 $\sum_i(\sigma_i - 1)^2$ 逐个比较奇异值与 1：正交矩阵的奇异值全为 1，最佳正交逼近只是把 $\boldsymbol{\Sigma}$ 换成 $\boldsymbol{I}$。

$\boldsymbol{A}$ 奇异时，最优解一般不唯一，而且最优解恰好是全部极分解的正交因子。一方面，若 $\boldsymbol{A} = \boldsymbol{W}'\boldsymbol{H}$ 是任一极分解，则 $\operatorname{tr}(\boldsymbol{W}'^{\top}\boldsymbol{A}) = \operatorname{tr}(\boldsymbol{W}'^{\top}\boldsymbol{W}'\boldsymbol{H}) = \operatorname{tr}\boldsymbol{H} = \sum_i \sigma_i$，达到上界。

另一方面，设 $r = \operatorname{rank}\boldsymbol{A}$，$\sigma_i = 0$（$i > r$）的项对迹没有贡献，等号只要求 $z_{i,i} = 1$（$i \le r$）。按上面的论证，$\boldsymbol{Z}$ 的前 r 列是 $\boldsymbol{e}_1, \dots, \boldsymbol{e}_r$；由正交性，其余各列与它们正交，于是 $\boldsymbol{Z} = \operatorname{diag}(\boldsymbol{I}_r, \boldsymbol{Z}')$，其中 $\boldsymbol{Z}'$ 是某个 $d-r$ 阶正交矩阵。$\boldsymbol{U}\boldsymbol{Z}$ 仍正交，且只改变了 $\boldsymbol{U}$ 的后 $d-r$ 列，这些列在 $\boldsymbol{U}\boldsymbol{\Sigma}$ 中都乘以零，所以 $\boldsymbol{A} = (\boldsymbol{U}\boldsymbol{Z})\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$ 也是 SVD，由定理 6.5，$\boldsymbol{R} = (\boldsymbol{U}\boldsymbol{Z})\boldsymbol{V}^{\top}$ 是极分解的正交因子。不同的 $\boldsymbol{Z}'$ 正对应第 6章所说零伸缩方向上不同的正交补全。

算法实现与算例 计算只需三步：求 $\boldsymbol{A}$ 的完整方阵 SVD；直接相乘得到 $\boldsymbol{R}_\star = \boldsymbol{U}\boldsymbol{V}^{\top}$；核验 $\boldsymbol{R}_\star^{\top}\boldsymbol{R}_\star = \boldsymbol{I}$，并比较误差平方与 $\sum_i(\sigma_i - 1)^2$。这里没有限制 $\det \boldsymbol{R}_\star$ 的符号，所得的可能是旋转，也可能包含反射。

示例 15.22 二阶正交逼近 取

$$\boldsymbol{A}=\begin{bmatrix}0&-2\\3&0\end{bmatrix}=\boldsymbol{U}\,\mathrm{diag}(3,2),\qquad \boldsymbol{U}=\begin{bmatrix}0&-1\\1&0\end{bmatrix},\quad \boldsymbol{V}=\boldsymbol{I}.$$

逐项核对：$\boldsymbol{U}\,\mathrm{diag}(3,2)$ 的第一列是 $3\boldsymbol{U}_{:,1}=(0,3)^{\top}$，第二列是 $2\boldsymbol{U}_{:,2}=(-2,0)^{\top}$，正是 $\boldsymbol{A}$；$\boldsymbol{U}$ 正交，奇异值 $3\geq 2$ 按降序排列。于是 $\boldsymbol{R}_{\star}=\boldsymbol{U}\boldsymbol{V}^{\top}=\boldsymbol{U}$，残差

$$\boldsymbol{A}-\boldsymbol{R}_{\star}=\begin{bmatrix}0&-1\\2&0\end{bmatrix},$$

平方误差为 $1+4=5=(3-1)^2+(2-1)^2$。$\boldsymbol{R}_{\star}$ 是逆时针旋转 90 度，与 $\det\boldsymbol{A}=6>0$ 一致。

第 6章贯穿使用的矩阵 $\boldsymbol{A}=\left[\begin{smallmatrix}0&-1\\3&0\end{smallmatrix}\right]$ 也可以这样核对。那里 $\boldsymbol{S}=\boldsymbol{A}^{\top}\boldsymbol{A}=\mathrm{diag}(9,1)$，奇异值为 3 与 1，最小平方误差为 $(3-1)^2+(1-1)^2=4$；直接计算也得 $\boldsymbol{A}-\boldsymbol{W}=\left[\begin{smallmatrix}0&0\\2&0\end{smallmatrix}\right]$，其 Frobenius 范数的平方为 4。含噪的旋转估计常用这一步，把一个近似正交的矩阵修正为正交矩阵。

算法分析 除一次 $d\times d$ 的 SVD 外，只需一次矩阵乘法，约 d^3 次乘法；SVD 本身的代价取决于所用算法，本书不作分析。$\boldsymbol{A}$ 可逆时最优解唯一，与所取的 SVD 无关；$\boldsymbol{A}$ 奇异时，不同的 SVD 可能给出不同的最优正交矩阵，它们的差别只在零奇异值方向上，误差相同。

最优解是在全部正交矩阵中取得的。$\boldsymbol{A}$ 可逆时，唯一的最优解 $\boldsymbol{W}$ 满足 $\det\boldsymbol{W}$ 与 $\det\boldsymbol{A}$ 同号（第 6.3节），所以 $\det\boldsymbol{A}<0$ 时它包含一次反射。若应用要求结果是旋转，就需要下一小节的修正。

15.5.2 旋转约束下的逼近

主要思想 刚体的姿态估计等问题要求结果是旋转，即正交且 $\det\boldsymbol{R}=1$；包含反射的正交矩阵不是允许的答案。于是在上一小节的迹问题中增加行列式约束：在 $\boldsymbol{R}^{\top}\boldsymbol{R}=\boldsymbol{I}$、$\det\boldsymbol{R}=1$ 下最大化 $\mathrm{tr}(\boldsymbol{R}^{\top}\boldsymbol{A})$。

记 $s=\det(\boldsymbol{U}\boldsymbol{V}^{\top})=\det\boldsymbol{U}\det\boldsymbol{V}$。正交矩阵的行列式是 ±1，所以 $s=\pm1$。若 $s=1$，上一小节的 $\boldsymbol{U}\boldsymbol{V}^{\top}$ 本身是旋转；它在更大的集合中最优，在旋转中当然也最优，行列式约束不起作用。若 $s=-1$，$\boldsymbol{U}\boldsymbol{V}^{\top}$ 不可行，需要新的上界。这时对任一旋转 $\boldsymbol{R}$，$\boldsymbol{Z}=\boldsymbol{U}^{\top}\boldsymbol{R}\boldsymbol{V}$ 正交，且

$$\det\boldsymbol{Z}=\det\boldsymbol{U}\cdot\det\boldsymbol{R}\cdot\det\boldsymbol{V}=s=-1.$$

上一小节的上界依赖 $\boldsymbol{Z}=\boldsymbol{I}$ 可以取到，现在 $\det\boldsymbol{I}=1$，这已不可能。下面的引理说明，行列式为 -1 的正交矩阵的迹至少比 d 小 2。

引理 15.23 行列式为负的正交矩阵的迹 设 $\boldsymbol{Z} \in \mathbb{R}^{d\times d}$ 正交且 $\det \boldsymbol{Z} = -1$，则存在单位向量 $\boldsymbol{x}$ 使 $\boldsymbol{Z}\boldsymbol{x} = -\boldsymbol{x}$，并且 $\operatorname{tr}\boldsymbol{Z} \le d-2$。

证明 先证 -1 是特征值。由 $\boldsymbol{Z}^{\top}\boldsymbol{Z} = \boldsymbol{I}$，$\boldsymbol{Z}+\boldsymbol{I} = \boldsymbol{Z}(\boldsymbol{I}+\boldsymbol{Z}^{\top}) = \boldsymbol{Z}(\boldsymbol{I}+\boldsymbol{Z})^{\top}$，取行列式得

$$\det(\boldsymbol{Z}+\boldsymbol{I}) = \det\boldsymbol{Z}\cdot\det(\boldsymbol{I}+\boldsymbol{Z}) = -\det(\boldsymbol{Z}+\boldsymbol{I}),$$

所以 $\det(\boldsymbol{Z}+\boldsymbol{I}) = 0$，存在单位向量 $\boldsymbol{x}$ 使 $\boldsymbol{Z}\boldsymbol{x} = -\boldsymbol{x}$。再由 $\boldsymbol{x} = \boldsymbol{Z}^{\top}\boldsymbol{Z}\boldsymbol{x} = -\boldsymbol{Z}^{\top}\boldsymbol{x}$，得 $\boldsymbol{Z}^{\top}\boldsymbol{x} = -\boldsymbol{x}$。

$d = 1$ 时 $\boldsymbol{Z} = (-1)$，$\operatorname{tr}\boldsymbol{Z} = -1 = d-2$。设 $d \ge 2$，把 $\boldsymbol{x}$ 扩充为 $\mathbb{R}^d$ 的标准正交基，排成正交矩阵 $\boldsymbol{Q} = [\boldsymbol{x}, \boldsymbol{Q}_2]$。由 $\boldsymbol{Z}\boldsymbol{x} = -\boldsymbol{x}$ 与 $\boldsymbol{Z}^{\top}\boldsymbol{x} = -\boldsymbol{x}$，$\boldsymbol{Q}_2^{\top}\boldsymbol{Z}\boldsymbol{x} = -\boldsymbol{Q}_2^{\top}\boldsymbol{x} = \boldsymbol{0}$，$\boldsymbol{x}^{\top}\boldsymbol{Z}\boldsymbol{Q}_2 = (\boldsymbol{Z}^{\top}\boldsymbol{x})^{\top}\boldsymbol{Q}_2 = \boldsymbol{0}$，于是

$$\boldsymbol{Q}^{\top}\boldsymbol{Z}\boldsymbol{Q} = \begin{bmatrix} -1 & \boldsymbol{0} \\ \boldsymbol{0} & \boldsymbol{Z}_2 \end{bmatrix}, \qquad \boldsymbol{Z}_2 = \boldsymbol{Q}_2^{\top}\boldsymbol{Z}\boldsymbol{Q}_2.$$

左端是正交矩阵的乘积，仍正交，所以 $\boldsymbol{Z}_2$ 的各列是单位向量，对角元都不超过 1，$\operatorname{tr}\boldsymbol{Z}_2 \le d-1$。迹在相似变换下不变，故 $\operatorname{tr}\boldsymbol{Z} = -1 + \operatorname{tr}\boldsymbol{Z}_2 \le d-2$。 ■

用特征值的语言看，同一结论是这样的：实正交矩阵的特征值模都为 1，非实特征值成共轭对出现，每对的乘积为 1、实部之和不超过 2；实特征值只能是 ± 1。行列式等于全部特征值之积，为 -1 时特征值 -1 必出现奇数次，至少一次；迹等于特征值之和，于是至多为 $(d-1)\cdot 1 + (-1) = d-2$。上面的证明只用实向量完成了同一论证。

定理 15.24 最佳旋转逼近 设 $\boldsymbol{A} \in \mathbb{R}^{d\times d}$ 有 SVD $\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}$，$\sigma_1 \ge \cdots \ge \sigma_d \ge 0$，$s = \det(\boldsymbol{U}\boldsymbol{V}^{\top})$，$\boldsymbol{D}_s = \operatorname{diag}(1,\dots,1,s)$。则对一切满足 $\boldsymbol{R}^{\top}\boldsymbol{R} = \boldsymbol{I}$、$\det\boldsymbol{R} = 1$ 的 $\boldsymbol{R}$，

$$\operatorname{tr}(\boldsymbol{R}^{\top}\boldsymbol{A}) \le \sum_{i=1}^{d-1}\sigma_i + s\,\sigma_d,$$

等号由 $\boldsymbol{R}_{\star} = \boldsymbol{U}\boldsymbol{D}_s\boldsymbol{V}^{\top}$ 取到。因此

$$\min_{\boldsymbol{R}^{\top}\boldsymbol{R}=\boldsymbol{I},\ \det\boldsymbol{R}=1} \|\boldsymbol{A}-\boldsymbol{R}\|_{\mathrm{F}}^2 = \sum_{i=1}^{d-1}(\sigma_i - 1)^2 + (\sigma_d - s)^2.$$

证明 $\boldsymbol{R}_\star$ 是正交矩阵的乘积，仍正交，且 $\det \boldsymbol{R}_\star = \det \boldsymbol{U} \cdot s \cdot \det \boldsymbol{V} = s^2 = 1$，所以它是旋转。

$s = 1$ 时 $\boldsymbol{D}_s = \boldsymbol{I}$，上界就是定理 15.21对全部正交矩阵给出的 $\sum_i \sigma_i$，在旋转中自然成立，且由 $\boldsymbol{R}_\star = \boldsymbol{U}\boldsymbol{V}^\top$ 取到。

设 $s = -1$。对任一旋转 $\boldsymbol{R}$，令 $\boldsymbol{Z} = \boldsymbol{U}^\top \boldsymbol{R} \boldsymbol{V}$，则 $\det \boldsymbol{Z} = -1$，由引理 15.23，$\operatorname{tr} \boldsymbol{Z} \le d - 2$。与上一小节相同，$\operatorname{tr}(\boldsymbol{R}^\top \boldsymbol{A}) = \sum_i \sigma_i z_{i,i}$。由 $|z_{i,i}| \le 1$ 得 $1 - z_{i,i} \ge 0$，又 $\sigma_i \ge \sigma_d$，所以

$$\sum_{i=1}^{d} \sigma_i - \operatorname{tr}(\boldsymbol{R}^\top \boldsymbol{A}) = \sum_{i=1}^{d} \sigma_i (1 - z_{i,i}) \ge \sigma_d \sum_{i=1}^{d} (1 - z_{i,i}) = \sigma_d (d - \operatorname{tr} \boldsymbol{Z}) \ge 2\sigma_d,$$

即 $\operatorname{tr}(\boldsymbol{R}^\top \boldsymbol{A}) \le \sum_{i<d} \sigma_i - \sigma_d$。$\boldsymbol{R} = \boldsymbol{R}_\star$ 时 $\boldsymbol{Z} = \boldsymbol{D}_s$，迹恰为 $\sum_{i<d} \sigma_i - \sigma_d$，等号成立。

最后代入展开式。由 $\|\boldsymbol{A}\|_{\mathrm{F}}^2 = \sum_i \sigma_i^2$ 与 $s^2 = 1$，

$$\sum_{i=1}^{d} \sigma_i^2 + d - 2\Big(\sum_{i=1}^{d-1} \sigma_i + s\sigma_d\Big) = \sum_{i=1}^{d-1} (\sigma_i - 1)^2 + (\sigma_d - s)^2.$$

■

修正只发生在最小奇异方向上。$\boldsymbol{R}_\star = \boldsymbol{U}\boldsymbol{D}_s\boldsymbol{V}^\top$ 与无约束解 $\boldsymbol{U}\boldsymbol{V}^\top$ 的差别，是把最后一对奇异方向的配对改为 $\boldsymbol{v}_d \mapsto s\boldsymbol{u}_d$。若把符号改放在第 i 个方向上，同样得到旋转，但迹损失 $2\sigma_i$；证明中的不等式说明，任何旋转的迹损失都至少是 $2\sigma_d$，所以放在最小奇异方向上损失最少。

$s = -1$ 时，最小平方误差比无行列式约束时增加 $(\sigma_d + 1)^2 - (\sigma_d - 1)^2 = 4\sigma_d$。$\boldsymbol{A}$ 可逆时，$\det \boldsymbol{A} = \det \boldsymbol{U} \det \boldsymbol{\Sigma} \det \boldsymbol{V}$ 且 $\det \boldsymbol{\Sigma} > 0$，所以 s 就是 $\det \boldsymbol{A}$ 的符号，与所取的 SVD 无关：$\det \boldsymbol{A} > 0$ 时约束不起作用，$\det \boldsymbol{A} < 0$ 时代价为 $4\sigma_d$。

$\sigma_d = 0$ 时，s 依赖 SVD 的选取：把 $\boldsymbol{u}_d$ 换成 $-\boldsymbol{u}_d$ 不改变 $\boldsymbol{A}$，却改变 $\det \boldsymbol{U}$ 的符号。但这时 $(\sigma_d - s)^2 = 1$ 与 s 无关，旋转约束的代价为零；而且两种选取给出同一个 $\boldsymbol{R}_\star$，因为符号同时出现在 $\boldsymbol{u}_d$ 与 s 中，乘积 $s\boldsymbol{u}_d$ 不变。

唯一性分两种情形说明。$\boldsymbol{A}$ 可逆且 $s = 1$ 时，无约束问题的唯一解 $\boldsymbol{W}$ 本身是旋转，所以它也是旋转约束下的唯一解。$\sigma_{d-1} > \sigma_d$ 时最优旋转也唯一：若 $\sigma_d > 0$ 且 $s = -1$，上面不等式取等要求 $(\sigma_i - \sigma_d)(1 - z_{i,i}) = 0$，从而 $i < d$ 时 $z_{i,i} = 1$，$\boldsymbol{Z}$ 的前 $d - 1$ 列是 $\boldsymbol{e}_1, \dots, \boldsymbol{e}_{d-1}$，最后一列只能是 $\pm\boldsymbol{e}_d$，行列式为 -1 又迫使它为 $-\boldsymbol{e}_d$，即 $\boldsymbol{Z} = \boldsymbol{D}_s$；若 $\sigma_d = 0$，先取使 $s = 1$ 的 SVD，取等要求 $z_{i,i} = 1$（$i < d$），同理 $\boldsymbol{Z} = \operatorname{diag}(1, \dots, 1, \pm 1)$，而 $\det \boldsymbol{Z} = s = 1$，故 $\boldsymbol{Z} = \boldsymbol{I}$。

最小奇异值重复且 $s=-1$，或 $\operatorname{rank}\boldsymbol{A}\le d-2$ 时，最优旋转可以不唯一，例子见下文。

算法实现与算例 计算在上一小节的基础上增加两步。第一，求完整方阵 SVD，奇异值按非增顺序排列，使最后一列 $\boldsymbol{u}_d$、$\boldsymbol{v}_d$ 对应最小奇异值。第二，计算 $s=\det\boldsymbol{U}\det\boldsymbol{V}$，构造 $\boldsymbol{D}_s$，相乘得 $\boldsymbol{R}_\star=\boldsymbol{U}\boldsymbol{D}_s\boldsymbol{V}^{\top}$。最后同时核验三项：$\boldsymbol{R}_\star^{\top}\boldsymbol{R}_\star=\boldsymbol{I}$，$\det\boldsymbol{R}_\star=1$，误差平方等于 $\sum_{i<d}(\sigma_i-1)^2+(\sigma_d-s)^2$。

示例 15.25 对角矩阵的旋转逼近 取 $\boldsymbol{A}=\operatorname{diag}(3,-1)$，$\det\boldsymbol{A}=-3<0$。可选

$$\boldsymbol{U}=\operatorname{diag}(1,-1),\qquad \boldsymbol{\Sigma}=\operatorname{diag}(3,1),\qquad \boldsymbol{V}=\boldsymbol{I},$$

核对 $\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\top}=\operatorname{diag}(3,-1)=\boldsymbol{A}$。无行列式约束的最优正交矩阵是 $\boldsymbol{U}\boldsymbol{V}^{\top}=\operatorname{diag}(1,-1)$，它是关于横轴的反射，误差平方为 $\|\operatorname{diag}(2,0)\|_{\mathrm{F}}^2=4=(3-1)^2+(1-1)^2$。

$s=\det\boldsymbol{U}=-1$，取 $\boldsymbol{D}_s=\operatorname{diag}(1,-1)$，得 $\boldsymbol{R}_\star=\boldsymbol{U}\boldsymbol{D}_s\boldsymbol{V}^{\top}=\boldsymbol{I}$，误差平方为 $\|\operatorname{diag}(2,-2)\|_{\mathrm{F}}^2=8$，比无约束时多 $4=4\sigma_2$。直接比较全部二阶旋转：$\boldsymbol{R}=\left[\begin{smallmatrix}\cos\theta & -\sin\theta\\ \sin\theta & \cos\theta\end{smallmatrix}\right]$ 给出 $\operatorname{tr}(\boldsymbol{R}^{\top}\boldsymbol{A})=3\cos\theta-\cos\theta=2\cos\theta$，只在 $\theta=0$ 处取最大值 $2=\sigma_1-\sigma_2$，所以 $\boldsymbol{R}_\star=\boldsymbol{I}$ 是唯一的最优旋转，与 $\sigma_1>\sigma_2$ 时的唯一性一致。

最小奇异值重复时，唯一性可能失败。取 $\boldsymbol{A}=\operatorname{diag}(1,-1)$，奇异值为 $1,1$，$s=-1$。对上面的任一旋转，$\operatorname{tr}(\boldsymbol{R}^{\top}\boldsymbol{A})=\cos\theta-\cos\theta=0$，所有旋转的误差平方都是 $\|\boldsymbol{A}\|_{\mathrm{F}}^2+2=4$，与公式 $(1-1)^2+(1+1)^2=4$ 一致，但最优旋转有无穷多个。$\operatorname{rank}\boldsymbol{A}\le d-2$ 时也有类似的自由度，例如 $\boldsymbol{A}=\boldsymbol{0}$ 时每个旋转都最优。

算法分析 与无约束情形相比，额外的工作只是求两个正交矩阵的行列式与一次对角缩放，主要代价仍是 SVD。是否需要修正完全由 s 决定，不必比较多个候选。

最小奇异值接近零时，s 对 $\boldsymbol{A}$ 的微小变化很敏感：$\det\boldsymbol{A}$ 接近零，它的符号可能被扰动改变，最优旋转随之跳到另一个。但对同一个 $\boldsymbol{A}$，两种符号给出的误差平方恰好相差 $4\sigma_d$，这时也很小，最优误差本身随 $\boldsymbol{A}$ 连续变化。所以这种情形下应报告最优误差，而不应把所得的旋转当作稳定的估计。

15.6 逼近结果的检验

前几节的最优解都由 SVD 读出，实际计算出的近似矩阵还要检验。检验回答三个问题：结果是否满足约束，残差是否达到理论下界，残差中哪一部分来自约束本身、哪一部分来自计算。三项检验都要用问题所规定的那一种误差范数；用别的范数评价，会把正确的结果误判为不好，或把不好的结果误判为可接受。

第一项是约束。低秩近似若以因子 $\boldsymbol{U}_k$、$\boldsymbol{\Sigma}_k$、$\boldsymbol{V}_k$ 的形式保存，秩不超过 k 由因子形式直接保证；若已经乘成完整矩阵 $\widehat{\boldsymbol{X}}$，可以看它第 k 个以后的奇异值是否只在舍入误差的量级。正交逼近与旋转逼近要检查 $\|\widehat{\boldsymbol{R}}^{\mathsf{T}}\widehat{\boldsymbol{R}}-\boldsymbol{I}\|_{\mathrm{F}}$ 是否接近零；旋转还要检查 $\det\widehat{\boldsymbol{R}}=1$，而不是 -1。

第二项是残差与理论下界的比较。直接计算残差，再与本章给出的最优误差对照：秩 k 逼近在 Frobenius 范数下为 $(\sum_{i>k}\sigma_i^2)^{1/2}$，在谱范数下为 σ_{k+1}；可分离权重下为 $(\sum_{i>k}\tilde{\sigma}_i^2)^{1/2}$；正交逼近的平方误差为 $\sum_i(\sigma_i-1)^2$，旋转逼近再加上 $s=-1$ 时的 $4\sigma_d$。

满足约束的任何候选，残差都不会低于这些下界。所以若直接算出的残差明显低于下界，说明结果实际上违反了约束（例如数值秩大于 k），或者所用的奇异值本身不准确；若明显高于下界，则说明计算或截断有误，例如奇异值没有按降序排列，或左右奇异向量的配对被打乱。加权问题要用加权残差比较：示例 15.20中的 $\boldsymbol{X}_1=\operatorname{diag}(0,2)$ 按普通 Frobenius 范数的误差为 3，比直接截断 $\boldsymbol{A}$ 的误差 2 大，但它在加权意义下才是最优的。

第三项是区分两种误差。逼近误差由约束决定：秩预算或正交性使 $\boldsymbol{A}$ 本身不可行时，即使精确计算，残差也等于理论下界而不为零，这部分不能靠提高计算精度消除。计算误差则是计算结果与精确最优解之间的差别，来自 SVD 等步骤的舍入，表现为直接残差与理论下界之间的差距，以及约束检验中偏离零的量。

两者对扰动的反应也不同。由第 7章奇异值的 Weyl 界（定理 7.15），$\boldsymbol{A}$ 受到谱范数不超过 ε 的扰动时，每个奇异值的变化不超过 ε，所以最优误差 σ_{k+1} 的数值是稳定的。取得最优误差的矩阵却依赖奇异子空间：间隙 $\sigma_k-\sigma_{k+1}$ 很小时，前 k 个奇异方向可能明显转动；间隙为零时，第 15.3.4节已经说明最优矩阵本身不唯一。因此间隙很小时，应把最优误差当作可靠的结论，而把具体的近似矩阵当作许多近乎同样好的候选之一。

本章的算例可以按这三项核对。示例 15.10中 $\boldsymbol{A}_1$ 秩为一，直接算出的残差为 $\sqrt{2}$（Frobenius）与 1（谱范数），分别等于 $(\sigma_2^2+\sigma_3^2)^{1/2}$ 与 σ_2；示例 15.22中 $\boldsymbol{R}_\star^{\mathsf{T}}\boldsymbol{R}_\star=\boldsymbol{I}$，平方误差 $5=(3-1)^2+(2-1)^2$；示例 15.25中 $\det\boldsymbol{R}_\star=1$，平方误差 $8=4+4\sigma_2$。这些都是精确算例，计算误差为零，残差全部来自约束。

最后区分本章的截断与第 14章的截断。那里的截断 SVD 求解 $\boldsymbol{x}_k = \boldsymbol{A}_k^{\dagger}\boldsymbol{b}$ 同样只保留前 k 个奇异方向，但目的是从带误差的观测中稳定地求出输入，检验的是向量残差 $\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}_k$ 与解的误差；选择 k 时，要同时比较舍弃方向带来的拟合损失与保留方向上 $1/\sigma_k$ 的噪声放大。本章检验的是矩阵残差 $\boldsymbol{A} - \boldsymbol{A}_k$，最佳矩阵逼近本身不替代那里对 k 的判断。

15.7 本章小结

本章开头的问题是：给定矩阵 $\boldsymbol{A}$，在秩约束或正交约束下，哪一个矩阵离它最近，最小误差是多少，最优矩阵是否唯一。各节的解法遵循同一条路线：先写清约束与误差；再固定一个表示，在其中选出最优系数；最后选择表示本身，即方向、子空间或正交因子。前两步把矩阵优化化成向量的投影与特征值比较，SVD 则把最优解写成具体的矩阵。

秩一逼近中，固定单位方向 $\boldsymbol{u}$ 时，最优系数是投影系数 $\boldsymbol{c} = \boldsymbol{A}^{\top}\boldsymbol{u}$，误差等于 $\|\boldsymbol{A}\|_{\mathrm{F}}^2$ 减去保留量 $\boldsymbol{u}^{\top}\boldsymbol{A}\boldsymbol{A}^{\top}\boldsymbol{u}$。选方向就是最大化 Rayleigh 商。对任意实对称 $\boldsymbol{S}$，Rayleigh 商介于最小、最大特征值之间，取等的方向恰是相应特征空间中的非零向量。用到 $\boldsymbol{A}\boldsymbol{A}^{\top}$ 上，最优秩一近似为 $\sigma_1\boldsymbol{u}_1\boldsymbol{v}_1^{\top}$，平方误差为 $\sum_{i\geq 2}\sigma_i^2$；它在 $\sigma_1 > \sigma_2$ 时唯一，奇异向量同时变号只改变写法。

秩 k 逼近中，固定子空间的最优重建是正交投影，选子空间化为迹极值：k 维子空间上的迹不超过前 k 个特征值之和。由此得到 Eckart–Young–Mirsky 定理：截断 SVD$\boldsymbol{A}_k$ 在全部秩不超过 k 的矩阵中同时使 Frobenius 误差与谱范数误差最小，最小值分别为 $(\sum_{i>k}\sigma_i^2)^{1/2}$ 与 σ_{k+1}。Frobenius 最优解在 $\sigma_k > \sigma_{k+1}$ 时唯一；谱范数最优解即使有间隙也一般不唯一。这些结论只对全部秩不超过 k 的矩阵与这两种范数成立，额外的非负、稀疏约束或一般的逐元素权重都会使截断 SVD 失去最优性。

改用加权长度规定单位方向时，Rayleigh 商推广为广义 Rayleigh 商。$\boldsymbol{B}$ 正定时，用 Gram 因子换元可化为普通 Rayleigh 商，极值是广义特征值，广义特征向量可以选成 $\boldsymbol{B}$ 正交；计算用 Cholesky 分解与三角求解保持对称结构，不应改求一般不对称的 $\boldsymbol{B}^{-1}\boldsymbol{S}$。$\boldsymbol{B}$ 不正定时这一化归失效。

误差的权重能分离为行权重与列权重时，加权低秩逼近经可逆变换化为普通低秩逼近，最优解由变换后矩阵的截断 SVD 还原，最佳方向正是一个广义 Rayleigh 商的最大特征向量。这一化归要求逐元素权重是行因子与列因子的乘积；任意权重与缺失元素没有截断 SVD 式的闭式解，交由卷五的优化方法处理。

正交约束下，距离最小化成迹最大化，目标关于未知矩阵是线性的。最优正交矩阵是 $\boldsymbol{U}\boldsymbol{V}^{\top}$，即第 6章极分解的正交因子，平方误差为 $\sum_i(\sigma_i-1)^2$；$\boldsymbol{A}$ 可逆时它唯一，奇异时自由度只在零奇异值方向上。要求旋转时，只需在最小

奇异方向上作符号修正，$\boldsymbol{R}_\star = \boldsymbol{U}\,\mathrm{diag}(1,\dots,1,\det(\boldsymbol{U}\boldsymbol{V}^\top))\boldsymbol{V}^\top$；$\det(\boldsymbol{U}\boldsymbol{V}^\top) = -1$ 时误差平方增加 $4\sigma_d$，$\sigma_d = 0$ 时修正不增加误差。

在这些问题中，Rayleigh 商、迹极值与截断 SVD 承担的是最优性工具的职责：它们说明为什么由 SVD 读出的矩阵最好，以及在什么条件下唯一。计算出的结果要按同一种误差范数检验约束与残差，把约束带来的逼近误差与计算误差分开；最优误差的数值对扰动稳定，最优矩阵在间隙小时则不稳定。本章的截断矩阵用于重建 $\boldsymbol{A}$ 本身，与第 14章为稳定求解方程而截断取逆的用途不同；不能化归到 SVD 的一般逼近问题，则由卷五的迭代优化展开。

第 16 章

矩阵方程

前面各章的未知量都是向量。有些问题的未知量却是一整张矩阵 $\boldsymbol{X}$，而且它同时受到已知矩阵的左乘和右乘。第 7章证明谱隙界时已经遇到这样的方程：未知矩阵左边乘一个对角矩阵、右边乘另一个，两项相减等于已知矩阵。第 8章的递推 $\boldsymbol{x}_{k+1} = \boldsymbol{A}\boldsymbol{x}_k$ 也提出类似的问题：若每一步以二次量计量状态，全部步骤的累计量能否由一个矩阵直接写出？这个矩阵满足的同样是一个左右两侧都有 $\boldsymbol{A}$ 作用的方程。

本章回答三个问题：这类方程何时对任意右端都唯一可解；怎样在不形成巨大系数矩阵的前提下算出解；对称右端的 Lyapunov 方程，解何时对称、何时正定，正定解又能证明什么。

第 16.1节研究 Sylvester 方程 $\boldsymbol{A}\boldsymbol{X} + \boldsymbol{X}\boldsymbol{B} = \boldsymbol{C}$。向量化说明它是矩阵空间上的线性方程，可解性由两侧系数的特征值之和决定；计算则用第 4章的实 Schur 形把两个系数化为准三角形，再像第 10章的三角回代那样逐块求解。可对角化时换到特征基更简单，但特征基不正交时误差会被放大。

第 16.2节由离散累计引出 Lyapunov 方程,并把连续型方程作为 Sylvester 方程的特例。两类方程只需一次 Schur 分解，就能保持对称结构逐元素递推。离散型的正定解由第 8章的矩阵幂几何上界和绝对收敛级数构造；连续型正定解的积分证明要用矩阵指数，留给后续关于演化的理论，本章只陈述条件并给出代数检验。

全章用 $\boldsymbol{X}$ 表示未知矩阵, Lyapunov 方程统一写成离散型 $\boldsymbol{X} - \boldsymbol{A}^{\top}\boldsymbol{X}\boldsymbol{A} = \boldsymbol{Q}$ 与连续型 $\boldsymbol{A}^{\top}\boldsymbol{X} + \boldsymbol{X}\boldsymbol{A} = -\boldsymbol{Q}$。无论哪种算法，最后都在原方程中计算残差，以它检验整个流程；Schur 路线的正交变换保证这个残差与变换后坐标中的残差相同。

16.1 Sylvester 方程

本节研究未知矩阵同时受左乘和右乘的 Sylvester 方程。先说明它是矩阵空间上的线性方程，再由两侧系数的特征值给出存在唯一性条件；计算时用正交 Schur 变换把方程化为准三角形后逐块回代，可对角化的系数还可

以换到特征基逐元素相除。两条计算路线都不形成巨大的 Kronecker 系数矩阵。

16.1.1 矩阵方程的线性算子表示

已知矩阵从左边、右边或两边作用在未知矩阵上，这样的方程称为**矩阵方程**（matrix equation）。最简单的是单侧方程 $\boldsymbol{A}\boldsymbol{X}=\boldsymbol{C}$：$\boldsymbol{X}$ 的每一列分别满足一个以 $\boldsymbol{A}$ 为系数的线性方程，所以它就是共用系数的多右端线性方程。双侧方程 $\boldsymbol{A}\boldsymbol{X}\boldsymbol{B}=\boldsymbol{C}$ 中，$\boldsymbol{A}$ 作用在 $\boldsymbol{X}$ 的列上，$\boldsymbol{B}$ 作用在 $\boldsymbol{X}$ 的行上；两侧系数可逆时，可以先左乘 $\boldsymbol{A}^{-1}$、再右乘 $\boldsymbol{B}^{-1}$，两次“除法”互不干扰。

本节研究左右两种作用相加的Sylvester 方程（Sylvester equation）

$$\boldsymbol{A}\boldsymbol{X}+\boldsymbol{X}\boldsymbol{B}=\boldsymbol{C},$$

其中 $\boldsymbol{A}\in\mathbb{R}^{m\times m}$、$\boldsymbol{B}\in\mathbb{R}^{d\times d}$、$\boldsymbol{C}\in\mathbb{R}^{m\times d}$，未知量 $\boldsymbol{X}\in\mathbb{R}^{m\times d}$。$\boldsymbol{A}$ 作用在 $\boldsymbol{X}$ 的列上，阶数等于 $\boldsymbol{X}$ 的行数；$\boldsymbol{B}$ 作用在 $\boldsymbol{X}$ 的行上，阶数等于 $\boldsymbol{X}$ 的列数。

两项相加以后，就不能分别“除以”两个系数。即使 $\boldsymbol{A}$ 可逆，左乘 $\boldsymbol{A}^{-1}$ 也只得到 $\boldsymbol{X}+\boldsymbol{A}^{-1}\boldsymbol{X}\boldsymbol{B}=\boldsymbol{A}^{-1}\boldsymbol{C}$，未知量仍同时出现在两项中。所以必须把左边整体看作一个作用在 $\boldsymbol{X}$ 上的映射。

记 $\mathcal{L}(\boldsymbol{X})=\boldsymbol{A}\boldsymbol{X}+\boldsymbol{X}\boldsymbol{B}$。由矩阵乘法的分配律，$\mathcal{L}$ 对 $\boldsymbol{X}$ 是线性的，所以 Sylvester 方程就是 md 维空间 $\mathbb{R}^{m\times d}$ 上的线性方程 $\mathcal{L}(\boldsymbol{X})=\boldsymbol{C}$。为了写出它的系数矩阵，把矩阵按列拉直，并使用第 1.4.3.1节的恒等式 $\operatorname{vec}(\boldsymbol{A}\boldsymbol{X}\boldsymbol{B})=(\boldsymbol{B}^{\top}\otimes\boldsymbol{A})\operatorname{vec}\boldsymbol{X}$。把 $\boldsymbol{A}\boldsymbol{X}$ 看成 $\boldsymbol{A}\boldsymbol{X}\boldsymbol{I}_d$、把 $\boldsymbol{X}\boldsymbol{B}$ 看成 $\boldsymbol{I}_m\boldsymbol{X}\boldsymbol{B}$，相加得

$$(\boldsymbol{I}_d\otimes\boldsymbol{A}+\boldsymbol{B}^{\top}\otimes\boldsymbol{I}_m)\operatorname{vec}\boldsymbol{X}=\operatorname{vec}\boldsymbol{C}. \tag{16.1}$$

记系数矩阵为 $\boldsymbol{K}\in\mathbb{R}^{md\times md}$。这一表达说明，前面关于线性方程的判据都适用于 Sylvester 方程；对小例子，也可以直接用 LU 分解（第 10.1节）求解式 (16.1)来核验。但 $\boldsymbol{K}$ 有 $(md)^2$ 个元素，$m=d=100$ 时已达 10^8 个，稠密消元约需 $\frac{2}{3}(md)^3$ 次运算。所以向量化只用来理解线性结构和判断可解性，大规模求解应保留矩阵形状。

16.1.2 可解性与唯一性条件

单侧方程可以直接沿用列空间判据：$\boldsymbol{A}\boldsymbol{X}=\boldsymbol{C}$ 相容，当且仅当 $\boldsymbol{C}$ 的每一列都在 $\operatorname{range}(\boldsymbol{A})$ 中，即 $\operatorname{rank}[\boldsymbol{A}\ \boldsymbol{C}]=\operatorname{rank}(\boldsymbol{A})$。双侧方程的相容性由向量化方程 $(\boldsymbol{B}^{\top}\otimes\boldsymbol{A})\operatorname{vec}\boldsymbol{X}=\operatorname{vec}\boldsymbol{C}$ 的增广秩判据判断。两侧系数都可逆时，唯一解为 $\boldsymbol{X}=\boldsymbol{A}^{-1}\boldsymbol{C}\boldsymbol{B}^{-1}$；任一侧秩亏时，方程可能无解，有解时解也可以沿该侧的零空间变动，因而不唯一。

Sylvester 方程不能这样逐侧处理，对角情形能看出原因。设 $\boldsymbol{A} = \operatorname{diag}(\lambda_1, \dots, \lambda_m)$、$\boldsymbol{B} = \operatorname{diag}(\mu_1, \dots, \mu_d)$，则 $\boldsymbol{AX}$ 把第 i 行乘以 λ_i，$\boldsymbol{XB}$ 把第 j 列乘以 μ_j。于是方程按元素分解为 $(\lambda_i + \mu_j) x_{i,j} = c_{i,j}$，分母非零时

$$x_{i,j} = \frac{c_{i,j}}{\lambda_i + \mu_j}. \tag{16.2}$$

若某个 $\lambda_i + \mu_j = 0$，该位置退化为 $0 \cdot x_{i,j} = c_{i,j}$：$c_{i,j} \neq 0$ 时无解，$c_{i,j} = 0$ 时 $x_{i,j}$ 可以任取。所以决定可解性的，是 $\boldsymbol{A}$ 的特征值与 $-\boldsymbol{B}$ 的特征值是否重合（图 16.1），而不是两侧系数各自是否可逆。一般情形的结论相同，只是实矩阵的特征值可能是复数，条件要在复数域中检查。下面记 $\operatorname{spec}(\boldsymbol{A})$ 为 $\boldsymbol{A}$ 在复数域中的全体特征值。

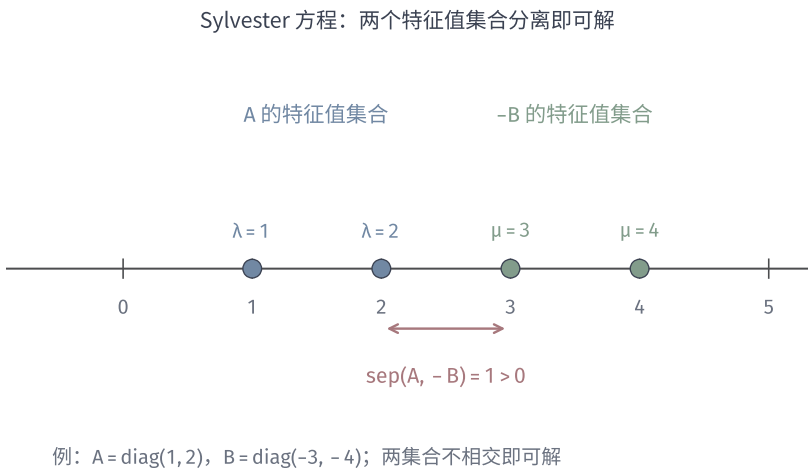


图 16.1　谱分离条件的实轴示意。$\boldsymbol{A} = \operatorname{diag}(1, 2)$ 的特征值 $\{1, 2\}$ 与 $-\boldsymbol{B}$（$\boldsymbol{B} = \operatorname{diag}(-3, -4)$）的特征值 $\{3, 4\}$ 不相交，最近一对相距 1，所以四个分母 $\lambda_i + \mu_j$ 都不为零，对任意 $\boldsymbol{C}$ 方程都有唯一解。

定理 16.1　Sylvester 方程的唯一可解性　设 $\boldsymbol{A} \in \mathbb{R}^{m \times m}$、$\boldsymbol{B} \in \mathbb{R}^{d \times d}$。方程 $\boldsymbol{AX} + \boldsymbol{XB} = \boldsymbol{C}$ 对每个 $\boldsymbol{C} \in \mathbb{R}^{m \times d}$ 都有唯一解，当且仅当

$$\operatorname{spec}(\boldsymbol{A}) \cap \operatorname{spec}(-\boldsymbol{B}) = \varnothing, \tag{16.3}$$

即对 $\boldsymbol{A}$ 的任一特征值 λ 与 $\boldsymbol{B}$ 的任一特征值 μ，都有 $\lambda + \mu \neq 0$。

证明 $\mathcal{L}$ 把 $\mathbb{R}^{m\times d}$ 映到自身。由秩零度定理，它对每个右端唯一可解，当且仅当齐次方程只有零解，也就是 $\det \boldsymbol{K} \neq 0$。这个行列式在实数域和复数域中是同一个数，所以可以在复数域中讨论齐次方程。

必要性。设 $\boldsymbol{A}\boldsymbol{u} = \lambda \boldsymbol{u}$，且 $-\lambda$ 是 $\boldsymbol{B}$ 的特征值。$\boldsymbol{B}^{\top}$ 与 $\boldsymbol{B}$ 有相同的特征多项式，所以 $-\lambda$ 也是 $\boldsymbol{B}^{\top}$ 的特征值，可取 $\boldsymbol{B}^{\top}\boldsymbol{w} = -\lambda \boldsymbol{w}$，其中 $\boldsymbol{u}, \boldsymbol{w} \neq \boldsymbol{0}$。于是 $\boldsymbol{X} = \boldsymbol{u}\boldsymbol{w}^{\top} \neq \boldsymbol{0}$ 满足 $\boldsymbol{A}\boldsymbol{X} + \boldsymbol{X}\boldsymbol{B} = \lambda \boldsymbol{u}\boldsymbol{w}^{\top} + \boldsymbol{u}(\boldsymbol{B}^{\top}\boldsymbol{w})^{\top} = \lambda \boldsymbol{u}\boldsymbol{w}^{\top} - \lambda \boldsymbol{u}\boldsymbol{w}^{\top} = \boldsymbol{0}$，齐次方程有非零解。

充分性。设 $\boldsymbol{A}\boldsymbol{X} + \boldsymbol{X}\boldsymbol{B} = \boldsymbol{0}$，即 $\boldsymbol{A}\boldsymbol{X} = \boldsymbol{X}(-\boldsymbol{B})$。归纳得 $\boldsymbol{A}^{k}\boldsymbol{X} = \boldsymbol{X}(-\boldsymbol{B})^{k}$，从而对任意多项式 p 有 $p(\boldsymbol{A})\boldsymbol{X} = \boldsymbol{X}\, p(-\boldsymbol{B})$。取 $p(z) = \prod_{k}(z - \lambda_k)$ 为 $\boldsymbol{A}$ 的特征多项式，由 Cayley–Hamilton 定理 4.5，$p(\boldsymbol{A}) = \boldsymbol{0}$。另一方面，$p(-\boldsymbol{B}) = \prod_{k}(-\boldsymbol{B} - \lambda_k \boldsymbol{I})$ 中每个 λ_k 都不是 $-\boldsymbol{B}$ 的特征值，各因子可逆，所以 $p(-\boldsymbol{B})$ 可逆。于是 $\boldsymbol{X}\, p(-\boldsymbol{B}) = \boldsymbol{0}$ 推出 $\boldsymbol{X} = \boldsymbol{0}$。 ■

这一条件与 $\boldsymbol{A}$、$\boldsymbol{B}$ 各自是否可逆无关。$\boldsymbol{A} = \boldsymbol{0}$、$\boldsymbol{B} = \boldsymbol{I}_d$ 时 $\boldsymbol{A}$ 不可逆，方程却化为 $\boldsymbol{X} = \boldsymbol{C}$，唯一可解；$1\times 1$ 情形 $\boldsymbol{A} = 2$、$\boldsymbol{B} = -2$ 都可逆，方程却是 $0 \cdot x = c$。

谱不相交只回答解是否唯一，不回答解对数据误差是否敏感。对角情形下，最小的 $|\lambda_i + \mu_j|$ 越接近零，$\boldsymbol{C}$ 的误差被放大得越多；矩阵远离正规时，即使所有谱和都远离零，解仍可能很敏感，第 16.1.4节会看到其中的原因。

16.1.3 Schur 分解法

稠密的一般 Sylvester 方程通常用Bartels–Stewart 算法（Bartels–Stewart algorithm）求解。它的思路与解三角方程组相同：先用正交相似把两个系数化为准上三角形，未知元之间就有了先后依赖，可以逐个回代。下面设谱条件 (16.3)成立，依次说明变换、回代次序和二阶块的处理，再给出算法步骤、算例与分析。

主要思想：正交变换到准三角形 第一步，分别对两个系数作实 Schur 分解（定理 4.26）

$$\boldsymbol{A} = \boldsymbol{U}\boldsymbol{T}\boldsymbol{U}^{\top}, \qquad \boldsymbol{B} = \boldsymbol{V}\boldsymbol{S}\boldsymbol{V}^{\top},$$

其中 $\boldsymbol{U}, \boldsymbol{V}$ 正交，$\boldsymbol{T}, \boldsymbol{S}$ 是准上三角矩阵，对角块为 1×1（实特征值）或 2×2（一对共轭复特征值）。这一步只依赖 $\boldsymbol{A}$、$\boldsymbol{B}$，与右端无关。

把分解代入 $\boldsymbol{A}\boldsymbol{X} + \boldsymbol{X}\boldsymbol{B} = \boldsymbol{C}$，得 $\boldsymbol{U}\boldsymbol{T}\boldsymbol{U}^{\top}\boldsymbol{X} + \boldsymbol{X}\boldsymbol{V}\boldsymbol{S}\boldsymbol{V}^{\top} = \boldsymbol{C}$。两边左乘 $\boldsymbol{U}^{\top}$、右乘 $\boldsymbol{V}$，利用 $\boldsymbol{U}^{\top}\boldsymbol{U} = \boldsymbol{I}$、$\boldsymbol{V}^{\top}\boldsymbol{V} = \boldsymbol{I}$，并记 $\boldsymbol{Y} = \boldsymbol{U}^{\top}\boldsymbol{X}\boldsymbol{V}$、$\boldsymbol{D} = \boldsymbol{U}^{\top}\boldsymbol{C}\boldsymbol{V}$，方程化为

$$\boldsymbol{T}\boldsymbol{Y} + \boldsymbol{Y}\boldsymbol{S} = \boldsymbol{D}. \tag{16.4}$$

$\boldsymbol{T}$ 与 $\boldsymbol{A}$、$\boldsymbol{S}$ 与 $\boldsymbol{B}$ 分别相似，特征值相同，所以新方程同样满足谱条件。正交变换还不改变 Frobenius 范数：任一近似解 $\boldsymbol{Z}$ 在原坐标中的残差，等于 $\boldsymbol{W} = \boldsymbol{U}^{\mathsf{T}}\boldsymbol{Z}\boldsymbol{V}$ 在新坐标中的残差（下面定理 16.4的第三条）。因此在新坐标中解得准确，换回原坐标后残差不会被放大。

主要思想：上三角情形的回代次序 先看 $\boldsymbol{T}$、$\boldsymbol{S}$ 都是上三角的情形。比较式 (16.4)两边的 (i,j) 元：$(\boldsymbol{T}\boldsymbol{Y})_{i,j} = \sum_{k\ge i} t_{i,k}y_{k,j}$，$(\boldsymbol{Y}\boldsymbol{S})_{i,j} = \sum_{\ell\le j} y_{i,\ell}s_{\ell,j}$。把含 $y_{i,j}$ 的两项留在左边，得

$$(t_{i,i} + s_{j,j})\,y_{i,j} = d_{i,j} - \sum_{k>i} t_{i,k}y_{k,j} - \sum_{\ell<j} y_{i,\ell}s_{\ell,j}. \tag{16.5}$$

右端第一个和只用同一列中更靠下的元素，第二个和只用同一行中更靠左的元素。所以按列 $j = 1,\dots,d$ 从左向右，每列内按行 $i = m,\dots,1$ 从下向上计算，每一步右端都已知。除数 $t_{i,i} + s_{j,j}$ 是 $\boldsymbol{A}$ 与 $\boldsymbol{B}$ 的一对特征值之和，由谱条件不为零。

同一次序也可以按整列写出。$\boldsymbol{Y}\boldsymbol{S}$ 的第 j 列是 $\sum_{\ell\le j} s_{\ell,j}\boldsymbol{y}_\ell$，比较式 (16.4)两边的第 j 列，得

$$(\boldsymbol{T} + s_{j,j}\boldsymbol{I}_m)\boldsymbol{y}_j = \boldsymbol{d}_j - \sum_{\ell<j} s_{\ell,j}\boldsymbol{y}_\ell.$$

右端只用到更靠左的列；每列的系数是上三角矩阵，用第 10.1节的回代从最后一行向上求解，逐行展开正是式 (16.5)。图 16.2画出了第 j 列的依赖：$\boldsymbol{S}$ 第 j 列中对角线以上的元素把已求出的列带进右端，对角元 $s_{j,j}$ 并入当前列的三角系数。

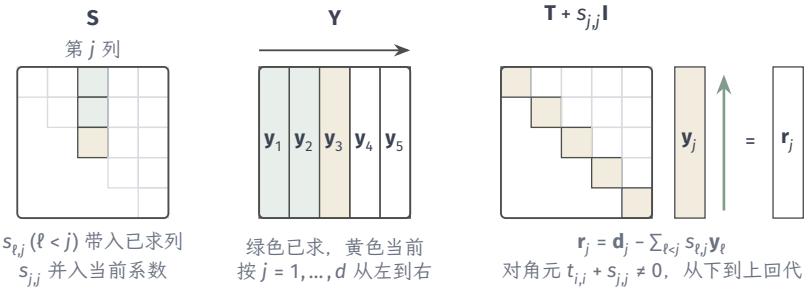


图 16.2 Bartels–Stewart 算法逐列求解 $\boldsymbol{T}\boldsymbol{Y} + \boldsymbol{Y}\boldsymbol{S} = \boldsymbol{D}$ 的次序（上三角情形，图中取当前列 $j = 3$）。左：$\boldsymbol{S}$ 的第 j 列，绿色元素 $s_{\ell,j}$（$\ell < j$）对应已求出的列，黄色为 $s_{j,j}$。中：$\boldsymbol{Y}$ 的列从左到右求出。右：当前列解一个对角元为 $t_{i,i} + s_{j,j}$ 的上三角方程组，从最后一行向上回代。

主要思想：二阶对角块的局部系统　实 Schur 形含 2×2 对角块时，把一个标量未知数换成一个未知子块。按 $\boldsymbol{T}$、$\boldsymbol{S}$ 的对角块把 $\boldsymbol{Y}$、$\boldsymbol{D}$ 分块，记 $\boldsymbol{T}$ 的第 I 个对角块为 $\boldsymbol{T}_{I,I}$、$\boldsymbol{S}$ 的第 J 个对角块为 $\boldsymbol{S}_{J,J}$，比较第 (I,J) 块得

$$\boldsymbol{T}_{I,I}\boldsymbol{Y}_{I,J}+\boldsymbol{Y}_{I,J}\boldsymbol{S}_{J,J}=\boldsymbol{D}_{I,J}-\sum_{K>I}\boldsymbol{T}_{I,K}\boldsymbol{Y}_{K,J}-\sum_{L<J}\boldsymbol{Y}_{I,L}\boldsymbol{S}_{L,J}.$$

右端只含同一块列中更靠下的块和更靠左的块列，因此按块列从左到右、每块列从下到上计算。

左边是一个小 Sylvester 方程，$\boldsymbol{Y}_{I,J}$ 至多是 2×2 的，至多含四个未知数。由式 (16.1)，它的向量化系数是 $\boldsymbol{I}\otimes\boldsymbol{T}_{I,I}+\boldsymbol{S}_{J,J}^{\top}\otimes\boldsymbol{I}$，至多为 4 阶，直接消元即可；只在这样的局部形成 Kronecker 系数。$\boldsymbol{T}_{I,I}$ 的特征值是 $\boldsymbol{A}$ 的特征值，$\boldsymbol{S}_{J,J}$ 的特征值是 $\boldsymbol{B}$ 的特征值，所以局部方程满足谱条件，由定理 16.1唯一可解。

算法实现　把上面三步连起来，Bartels–Stewart 算法如下。

1. 计算实 Schur 分解 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{T}\boldsymbol{U}^{\top}$、$\boldsymbol{B}=\boldsymbol{V}\boldsymbol{S}\boldsymbol{V}^{\top}$，并变换右端 $\boldsymbol{D}=\boldsymbol{U}^{\top}\boldsymbol{C}\boldsymbol{V}$。
2. 按块列从左到右、每块列从下到上的次序，对每个块 (I,J) 从 $\boldsymbol{D}_{I,J}$ 中减去已求出块的贡献，再解至多四个未知数的局部方程，得 $\boldsymbol{Y}_{I,J}$。
3. 恢复原未知量 $\boldsymbol{X}=\boldsymbol{U}\boldsymbol{Y}\boldsymbol{V}^{\top}$，并在原方程中计算残差 $\boldsymbol{A}\boldsymbol{X}+\boldsymbol{X}\boldsymbol{B}-\boldsymbol{C}$。精确算术下它为零；浮点计算中它的 Frobenius 范数与新坐标中的残差相同，可以直接用来检验整个流程。

局部方程的系数接近奇异时，除法会放大误差，中间量也可能溢出。数值软件库中的实现因此常引入一个缩放因子 $\sigma\in(0,1]$，实际求解 $\boldsymbol{T}\boldsymbol{Y}+\boldsymbol{Y}\boldsymbol{S}=\sigma\boldsymbol{D}$，再连同 σ 一起返回，并对过小的局部分母给出警告。使用者应把 $\sigma<1$ 或这类警告视为方程接近不可解的信号，而不是忽略它。

示例 16.2　Schur 形方程的逐元素回代　先跳过 Schur 分解，直接从已为 Schur 形的系数出发，看逐元素回代应按什么次序进行。取

$$\boldsymbol{T}=\begin{bmatrix}1&2\\0&3\end{bmatrix},\quad \boldsymbol{S}=\begin{bmatrix}4&1\\0&5\end{bmatrix},\quad \boldsymbol{D}=\begin{bmatrix}11&21\\21&35\end{bmatrix}.$$

谱和 $t_{i,i}+s_{j,j}$ 为 $5,6,7,8$，都不为零，每个局部方程都可以相除。按式 (16.5)，第 1 列从下向上：

$$y_{2,1}=\frac{21}{3+4}=3,\qquad y_{1,1}=\frac{11-t_{1,2}y_{2,1}}{1+4}=\frac{11-2\cdot 3}{5}=1.$$

第 2 列从下向上，右端还要减去左边一列经 $s_{1,2}=1$ 带来的贡献：

$$y_{2,2}=\frac{35-y_{2,1}s_{1,2}}{3+5}=\frac{35-3}{8}=4,$$
$$y_{1,2}=\frac{21-t_{1,2}y_{2,2}-y_{1,1}s_{1,2}}{1+5}=\frac{21-8-1}{6}=2.$$

于是 $\boldsymbol{Y}=\left[\begin{smallmatrix}1&2\\3&4\end{smallmatrix}\right]$。代回全部四个元素：$\boldsymbol{TY}=\left[\begin{smallmatrix}7&10\\9&12\end{smallmatrix}\right]$，$\boldsymbol{YS}=\left[\begin{smallmatrix}4&11\\12&23\end{smallmatrix}\right]$，和为 $\left[\begin{smallmatrix}11&21\\21&35\end{smallmatrix}\right]=\boldsymbol{D}$。若次序颠倒，例如先算 $y_{1,1}$，它的右端需要尚未求出的 $y_{2,1}$，回代无法进行。

上例跳过了 Schur 分解。下面的例子从一般系数出发，完整走一遍变换、回代和恢复。

示例 16.3　Bartels–Stewart 求解一个二阶方程　取

$$\boldsymbol{A}=\begin{bmatrix}-2&3\\-4&5\end{bmatrix},\quad \boldsymbol{B}=\begin{bmatrix}1&1\\0&3\end{bmatrix},\quad \boldsymbol{C}=\begin{bmatrix}1&12\\-2&21\end{bmatrix}.$$

$\boldsymbol{A}$ 的特征值为 $2,1$，$-\boldsymbol{B}$ 的特征值为 $-1,-3$，谱条件成立。实 Schur 分解：由 $\boldsymbol{A}(3,4)^{\mathsf T}=2(3,4)^{\mathsf T}$ 取 $\boldsymbol{U}=\frac{1}{5}\left[\begin{smallmatrix}3&-4\\4&3\end{smallmatrix}\right]$，得 $\boldsymbol{T}=\boldsymbol{U}^{\mathsf T}\boldsymbol{A}\boldsymbol{U}=\left[\begin{smallmatrix}2&7\\0&1\end{smallmatrix}\right]$；$\boldsymbol{B}$ 已是上三角，取 $\boldsymbol{V}=\boldsymbol{I}$、$\boldsymbol{S}=\boldsymbol{B}$。变换右端得 $\boldsymbol{D}=\boldsymbol{U}^{\mathsf T}\boldsymbol{C}=\left[\begin{smallmatrix}-1&24\\-2&3\end{smallmatrix}\right]$。

在 Schur 坐标下逐列求解。第 1 列解 $(\boldsymbol{T}+s_{1,1}\boldsymbol{I})\boldsymbol{y}_1=\boldsymbol{d}_1$，即 $\left[\begin{smallmatrix}3&7\\0&2\end{smallmatrix}\right]\boldsymbol{y}_1=(-1,-2)^{\mathsf T}$，从下往上得 $y_{2,1}=-1$、$y_{1,1}=2$；第 2 列的右端为 $\boldsymbol{d}_2-s_{1,2}\boldsymbol{y}_1=(24,3)^{\mathsf T}-(2,-1)^{\mathsf T}=(22,4)^{\mathsf T}$，解 $\left[\begin{smallmatrix}5&7\\0&4\end{smallmatrix}\right]\boldsymbol{y}_2=(22,4)^{\mathsf T}$ 得 $y_{2,2}=1$、$y_{1,2}=3$。变回原坐标，

$$\boldsymbol{X}=\boldsymbol{U}\boldsymbol{Y}=\frac{1}{5}\begin{bmatrix}3&-4\\4&3\end{bmatrix}\begin{bmatrix}2&3\\-1&1\end{bmatrix}=\begin{bmatrix}2&1\\1&3\end{bmatrix}.$$

核验：$\boldsymbol{AX}=\left[\begin{smallmatrix}-1&7\\-3&11\end{smallmatrix}\right]$，$\boldsymbol{XB}=\left[\begin{smallmatrix}2&5\\1&10\end{smallmatrix}\right]$，和为 $\boldsymbol{C}$，原方程残差为零。

算法分析：正确性　上面的推导说明每一步都能进行，而且按次序算出的块满足各自的块等式。把这些事实合在一起，就得到算法的正确性和残差检验的依据。

定理 16.4　Bartels–Stewart 算法的正确性　设 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{T}\boldsymbol{U}^{\mathsf T}$、$\boldsymbol{B}=\boldsymbol{V}\boldsymbol{S}\boldsymbol{V}^{\mathsf T}$ 是实 Schur 分解，谱条件 (16.3)成立，$\boldsymbol{D}=\boldsymbol{U}^{\mathsf T}\boldsymbol{C}\boldsymbol{V}$。则

1. 按块列从左到右、每块列从下到上的次序，每一步的局部方程 $\boldsymbol{T}_{I,I}\boldsymbol{Y}_{I,J}+\boldsymbol{Y}_{I,J}\boldsymbol{S}_{J,J}=\boldsymbol{E}_{I,J}$ 都唯一可解，其中右端 $\boldsymbol{E}_{I,J}$ 由已求出的块给出；

2. 由此算出的 $\boldsymbol{Y}$ 是方程 (16.4)的唯一解，$\boldsymbol{X}=\boldsymbol{U}\boldsymbol{Y}\boldsymbol{V}^{\top}$ 是 $\boldsymbol{A}\boldsymbol{X}+\boldsymbol{X}\boldsymbol{B}=\boldsymbol{C}$ 的唯一解；
3. 对任意 $\boldsymbol{Z}\in\mathbb{R}^{m\times d}$，记 $\boldsymbol{W}=\boldsymbol{U}^{\top}\boldsymbol{Z}\boldsymbol{V}$，有 $\|\boldsymbol{A}\boldsymbol{Z}+\boldsymbol{Z}\boldsymbol{B}-\boldsymbol{C}\|_{\mathrm{F}}=\|\boldsymbol{T}\boldsymbol{W}+\boldsymbol{W}\boldsymbol{S}-\boldsymbol{D}\|_{\mathrm{F}}$。

证明　先证第三条。由 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{T}\boldsymbol{U}^{\top}$、$\boldsymbol{B}=\boldsymbol{V}\boldsymbol{S}\boldsymbol{V}^{\top}$ 与 $\boldsymbol{Z}=\boldsymbol{U}\boldsymbol{W}\boldsymbol{V}^{\top}$，

$$\boldsymbol{A}\boldsymbol{Z}+\boldsymbol{Z}\boldsymbol{B}-\boldsymbol{C}=\boldsymbol{U}(\boldsymbol{T}\boldsymbol{W}+\boldsymbol{W}\boldsymbol{S}-\boldsymbol{D})\boldsymbol{V}^{\top},$$

而左右乘正交矩阵不改变 Frobenius 范数。

再证第一条。准上三角矩阵的特征值是各对角块特征值的并，$\boldsymbol{T}$ 与 $\boldsymbol{A}$ 相似，所以 $\boldsymbol{T}_{I,I}$ 的特征值都是 $\boldsymbol{A}$ 的特征值；同理 $\boldsymbol{S}_{J,J}$ 的特征值都是 $\boldsymbol{B}$ 的特征值。于是每个局部方程满足谱条件，由定理 16.1唯一可解。

最后证第二条。第 (I,J) 块等式的右端只含按次序已算出的块，所以算出的每一块都满足相应的块等式；全部块等式合起来就是式 (16.4)。$\boldsymbol{T}$、$\boldsymbol{S}$ 满足谱条件，由定理 16.1，这个解唯一。在第三条中取 $\boldsymbol{Z}=\boldsymbol{X}$、$\boldsymbol{W}=\boldsymbol{Y}$，得原方程残差为零；原方程的唯一性同样由该定理给出。 ■

算法分析：计算代价　实 Schur 分解靠迭代算出，常用实现计入正交因子约需 $25m^3$ 与 $25d^3$ 次运算[1]。变换右端与变回原坐标各约 $2(m^2d+md^2)$ 次，逐块回代约 m^2d+md^2 次；存储只需 $O(m^2+d^2+md)$ 个数。$m=d=100$ 时总量约 6×10^7 次，而对式 (16.1)作稠密 LU 约需 7×10^{11} 次，并要存储 10^8 个数。多组右端共用 $\boldsymbol{A}$、$\boldsymbol{B}$ 时，两个 Schur 分解只做一次，每增加一个右端只增加 $O(m^2d+md^2)$ 次运算。

16.1.4　特征基下的求解

当 $\boldsymbol{A}$、$\boldsymbol{B}$ 都可对角化时，可以换到各自的特征基，把方程化为式 (16.2)的对角情形。设 $\boldsymbol{A}=\boldsymbol{P}\boldsymbol{\Lambda}\boldsymbol{P}^{-1}$、$\boldsymbol{B}=\boldsymbol{R}\boldsymbol{M}\boldsymbol{R}^{-1}$，其中 $\boldsymbol{\Lambda}=\operatorname{diag}(\lambda_i)$、$\boldsymbol{M}=\operatorname{diag}(\mu_j)$。这条路线公式最简短，代价是换基矩阵一般不正交。

主要思想：换到特征基　记 $\boldsymbol{Y}=\boldsymbol{P}^{-1}\boldsymbol{X}\boldsymbol{R}$、$\boldsymbol{D}=\boldsymbol{P}^{-1}\boldsymbol{C}\boldsymbol{R}$。方程左乘 $\boldsymbol{P}^{-1}$、右乘 $\boldsymbol{R}$，由 $\boldsymbol{P}^{-1}\boldsymbol{A}=\boldsymbol{\Lambda}\boldsymbol{P}^{-1}$ 与 $\boldsymbol{B}\boldsymbol{R}=\boldsymbol{R}\boldsymbol{M}$ 化为 $\boldsymbol{\Lambda}\boldsymbol{Y}+\boldsymbol{Y}\boldsymbol{M}=\boldsymbol{D}$。这时各坐标完全解耦，逐元素得到

$$(\lambda_i+\mu_j)\,y_{i,j}=d_{i,j}.$$

谱条件成立时所有分母非零，$y_{i,j} = d_{i,j}/(\lambda_i + \mu_j)$。若某个 $\lambda_i + \mu_j = 0$，就要区分两种情形：$d_{i,j} \neq 0$ 时这个坐标无解，$d_{i,j} = 0$ 时 $y_{i,j}$ 是自由变量。注意检查的是变换后的 $d_{i,j}$，而不是原右端的 $c_{i,j}$。

主要思想：恢复原未知量 恢复公式为 $\boldsymbol{X} = \boldsymbol{P}\boldsymbol{Y}\boldsymbol{R}^{-1}$，次序与换基相反。与 Schur 路线不同，这里的换基矩阵 $\boldsymbol{P}$、$\boldsymbol{R}$ 一般不正交：变换右端和还原解时，误差可能被放大 $\kappa_2(\boldsymbol{P})\kappa_2(\boldsymbol{R})$ 量级，所以实现前要检查两组特征基的条件数（见下面的算法分析）。实矩阵有复特征值时，$\boldsymbol{P}$、$\boldsymbol{R}$ 为复矩阵，全程用复数运算，最后舍去舍入产生的虚部。

算法实现 算法依次执行以下步骤。

1. 核验两组特征基可逆且条件数可以接受；若特征基不满秩或接近奇异，改用第 16.1.3节的 Schur 路线，不尝试直接求逆。
2. 变换右端时不求逆：先对 $\boldsymbol{P}$ 作 LU 分解，对 $\boldsymbol{C}$ 的各列求解 $\boldsymbol{P}\boldsymbol{Z} = \boldsymbol{C}$，再令 $\boldsymbol{D} = \boldsymbol{Z}\boldsymbol{R}$。
3. 逐项检查谱和 $\lambda_i + \mu_j$ 并相除，得 $\boldsymbol{Y}$。
4. 先算 $\boldsymbol{W} = \boldsymbol{P}\boldsymbol{Y}$，再利用 $\boldsymbol{R}$ 的 LU 分解求解 $\boldsymbol{X}\boldsymbol{R} = \boldsymbol{W}$，得 $\boldsymbol{X} = \boldsymbol{P}\boldsymbol{Y}\boldsymbol{R}^{-1}$；最后在原方程中计算残差。

示例 16.5　对角系数下的逐元素相除与零谱和 取 $\boldsymbol{A} = \operatorname{diag}(1,2)$、$\boldsymbol{B} = \operatorname{diag}(3,4)$、$\boldsymbol{C} = \left[\begin{smallmatrix} 4 & 10 \\ 15 & 24 \end{smallmatrix}\right]$。这时 $\boldsymbol{P} = \boldsymbol{R} = \boldsymbol{I}$，$\boldsymbol{D} = \boldsymbol{C}$，四个谱和为 $1+3=4$、$1+4=5$、$2+3=5$、$2+4=6$。逐元素相除得

$$x_{1,1} = \frac{4}{4} = 1, \quad x_{1,2} = \frac{10}{5} = 2, \quad x_{2,1} = \frac{15}{5} = 3, \quad x_{2,2} = \frac{24}{6} = 4,$$

即 $\boldsymbol{X} = \left[\begin{smallmatrix} 1 & 2 \\ 3 & 4 \end{smallmatrix}\right]$。四个元素互不耦合，每个只需一次除法。代回：$\boldsymbol{A}\boldsymbol{X} = \left[\begin{smallmatrix} 1 & 2 \\ 6 & 8 \end{smallmatrix}\right]$，$\boldsymbol{X}\boldsymbol{B} = \left[\begin{smallmatrix} 3 & 8 \\ 9 & 16 \end{smallmatrix}\right]$，和为 $\boldsymbol{C}$。

再把右下角的谱和改为零：令 $\boldsymbol{B} = \operatorname{diag}(3,-2)$，则 $\lambda_2 + \mu_2 = 0$，其余三个谱和 $4, -1, 5$ 仍非零。第 $(2,2)$ 个方程变为 $0 \cdot x_{2,2} = c_{2,2}$。右端保持 $c_{2,2} = 24 \neq 0$ 时，方程无解；把右端改为 $c_{2,2} = 0$ 时，$x_{1,1}, x_{1,2}, x_{2,1}$ 仍由各自的除法唯一确定，$x_{2,2}$ 可以任取，解集是一条直线。

对角系数无须换基。下面的例子换到非正交的特征基，再除以谱和、还原。

示例 16.6　特征基下的逐元素求解　取

$$\boldsymbol{A}=\begin{bmatrix}1&1\\0&2\end{bmatrix},\quad \boldsymbol{B}=\begin{bmatrix}3&1\\0&4\end{bmatrix},\quad \boldsymbol{C}=\begin{bmatrix}7&12\\15&21\end{bmatrix}.$$

两者的特征向量都是 $(1,0)^{\mathsf T}$ 与 $(1,1)^{\mathsf T}$，故 $\boldsymbol{P}=\boldsymbol{R}=\left[\begin{smallmatrix}1&1\\0&1\end{smallmatrix}\right]$，特征值分别为 $1,2$ 与 $3,4$，四个分母 $\lambda_i+\mu_j$ 为 $4,5,5,6$。换基、逐元素相除、再变回，依次得

$$\boldsymbol{D}=\boldsymbol{P}^{-1}\boldsymbol{C}\boldsymbol{R}=\begin{bmatrix}-8&-17\\15&36\end{bmatrix},\qquad \boldsymbol{Y}=\begin{bmatrix}-2&-17/5\\3&6\end{bmatrix},$$

$$\boldsymbol{X}=\boldsymbol{P}\boldsymbol{Y}\boldsymbol{R}^{-1}=\begin{bmatrix}1&8/5\\3&3\end{bmatrix}.$$

代回有 $\boldsymbol{A}\boldsymbol{X}=\left[\begin{smallmatrix}4&23/5\\6&6\end{smallmatrix}\right]$、$\boldsymbol{X}\boldsymbol{B}=\left[\begin{smallmatrix}3&37/5\\9&15\end{smallmatrix}\right]$，和为 $\boldsymbol{C}$，残差为零。

若把 $\boldsymbol{B}$ 的 $(1,1)$ 元改为 -2，则 $\mu_1=-2$，$\lambda_2+\mu_1=0$。这时 $\boldsymbol{B}$ 的特征基也随之改变，第 $(2,1)$ 个方程变为 $0\cdot y_{2,1}=d_{2,1}$，其中 $d_{2,1}$ 是按新的特征基变换后的右端：$d_{2,1}\neq 0$ 时无解，$d_{2,1}=0$ 时解不唯一。

算法分析：数值敏感度　这条路线只在特征基接近正交时可靠。记 $\delta_{\min}=\min_{i,j}|\lambda_i+\mu_j|$，则 $\|\boldsymbol{Y}\|_{\mathrm F}\le\|\boldsymbol{D}\|_{\mathrm F}/\delta_{\min}$。再对 $\boldsymbol{D}=\boldsymbol{P}^{-1}\boldsymbol{C}\boldsymbol{R}$ 与 $\boldsymbol{X}=\boldsymbol{P}\boldsymbol{Y}\boldsymbol{R}^{-1}$ 使用 $\|\boldsymbol{M}_1\boldsymbol{Z}\boldsymbol{M}_2\|_{\mathrm F}\le\|\boldsymbol{M}_1\|_2\|\boldsymbol{Z}\|_{\mathrm F}\|\boldsymbol{M}_2\|_2$，只能得到

$$\|\boldsymbol{X}\|_{\mathrm F}\le\frac{\kappa_2(\boldsymbol{P})\,\kappa_2(\boldsymbol{R})}{\delta_{\min}}\|\boldsymbol{C}\|_{\mathrm F},$$

所以在斜基下，谱和远离零并不独自保证良好条件。

换基本身也会放大误差：$\boldsymbol{P}^{-1}\boldsymbol{C}$ 的元素可以比 $\boldsymbol{C}$ 大 $\kappa_2(\boldsymbol{P})$ 量级，变回时再相互抵消。例如 $0<\epsilon\ll 1$ 时，$\boldsymbol{A}=\left[\begin{smallmatrix}1&1\\0&1+\epsilon\end{smallmatrix}\right]$ 的特征向量 $(1,0)^{\mathsf T}$ 与 $(1,\epsilon)^{\mathsf T}$ 几乎平行，$\kappa_2(\boldsymbol{P})\ge 1/\epsilon$，中间量的大小约为 $1/\epsilon$，舍入误差随之被放大。

$\boldsymbol{A}$、$\boldsymbol{B}$ 实对称时，谱定理 4.21给出正交特征基，$\kappa_2=1$，元素公式既简单又可靠。一般情形即使可以对角化，也宜使用第 16.1.3节的正交 Schur 变换。

16.2　Lyapunov 方程

第 8章研究了反复作用 $\boldsymbol{x}_{k+1}=\boldsymbol{A}\boldsymbol{x}_k$ 的长期行为。若每一步以二次量 $\boldsymbol{x}_k^{\mathsf T}\boldsymbol{Q}\boldsymbol{x}_k$ 计量状态的大小，能否用一个矩阵 $\boldsymbol{X}$ 直接写出全部步骤的累计量 $\boldsymbol{x}_0^{\mathsf T}\boldsymbol{X}\boldsymbol{x}_0$？本节由这一离散累计引出 Lyapunov 方程，并把相应的连续型方程作为 Sylvester 方程的特例处理。

全节统一采用两种写法：离散型 $\boldsymbol{X}-\boldsymbol{A}^{\top}\boldsymbol{X}\boldsymbol{A}=\boldsymbol{Q}$，连续型 $\boldsymbol{A}^{\top}\boldsymbol{X}+\boldsymbol{X}\boldsymbol{A}=-\boldsymbol{Q}$，其中 $\boldsymbol{Q}$ 对称，未知量 $\boldsymbol{X}$ 与上一节一样记为 $\boldsymbol{X}$。两者都是左乘 $\boldsymbol{A}^{\top}$、右乘 $\boldsymbol{A}$，所以只需对 $\boldsymbol{A}$ 作一次 Schur 分解，回代次序也相同。离散型的正定性论证只用矩阵幂和级数；连续型正定解的积分证明需要矩阵指数，本节只陈述条件并给出代数检验。

16.2.1 离散型与连续型方程

设 $\boldsymbol{A}\in\mathbb{R}^{d\times d}$，$\boldsymbol{Q}=\boldsymbol{Q}^{\top}\succeq 0$，$\boldsymbol{x}_k=\boldsymbol{A}^k\boldsymbol{x}_0$。前 $N+1$ 步的累计量为

$$\sum_{k=0}^{N}\boldsymbol{x}_k^{\top}\boldsymbol{Q}\boldsymbol{x}_k=\boldsymbol{x}_0^{\top}\boldsymbol{X}_N\boldsymbol{x}_0,\qquad \boldsymbol{X}_N=\sum_{k=0}^{N}(\boldsymbol{A}^{\top})^k\boldsymbol{Q}\boldsymbol{A}^k,$$

其中 $\boldsymbol{X}_N$ 与初值无关。把和式的首项单独写出，其余各项提出左右的 $\boldsymbol{A}^{\top}$ 与 $\boldsymbol{A}$，得递推 $\boldsymbol{X}_{N+1}=\boldsymbol{Q}+\boldsymbol{A}^{\top}\boldsymbol{X}_N\boldsymbol{A}$。若 $\boldsymbol{X}_N$ 收敛到 $\boldsymbol{X}$，对递推取极限，极限应满足离散型Lyapunov 方程（Lyapunov equation）

$$\boldsymbol{X}-\boldsymbol{A}^{\top}\boldsymbol{X}\boldsymbol{A}=\boldsymbol{Q}. \tag{16.6}$$

它是矩阵空间上固定更新 $\boldsymbol{X}\mapsto\boldsymbol{Q}+\boldsymbol{A}^{\top}\boldsymbol{X}\boldsymbol{A}$ 的不动点方程。

方程 (16.6)也可以逐步读出。若 $\boldsymbol{X}$ 是解，则沿轨迹有

$$\boldsymbol{x}_{k+1}^{\top}\boldsymbol{X}\boldsymbol{x}_{k+1}-\boldsymbol{x}_k^{\top}\boldsymbol{X}\boldsymbol{x}_k=\boldsymbol{x}_k^{\top}(\boldsymbol{A}^{\top}\boldsymbol{X}\boldsymbol{A}-\boldsymbol{X})\boldsymbol{x}_k=-\boldsymbol{x}_k^{\top}\boldsymbol{Q}\boldsymbol{x}_k,$$

即二次量 $\boldsymbol{x}^{\top}\boldsymbol{X}\boldsymbol{x}$ 每走一步恰好减少这一步的计量 $\boldsymbol{x}_k^{\top}\boldsymbol{Q}\boldsymbol{x}_k$。把这些等式从 $k=0$ 加到 N，就回到上面的累计量。

离散型方程不是替换系数后的 Sylvester 方程：左边是恒等作用减去双侧作用，向量化后的系数矩阵为 $\boldsymbol{I}-\boldsymbol{A}^{\top}\otimes\boldsymbol{A}^{\top}$。相应地，唯一可解的条件由特征值的乘积而不是和决定。下面的定理对两侧系数不同的一般形式陈述，后面处理 Schur 形的局部块时要用到这一形式。

定理 16.7　离散型方程的唯一可解性　设 $\boldsymbol{G}\in\mathbb{R}^{m\times m}$、$\boldsymbol{H}\in\mathbb{R}^{d\times d}$。方程 $\boldsymbol{Y}-\boldsymbol{G}^{\top}\boldsymbol{Y}\boldsymbol{H}=\boldsymbol{E}$ 对每个 $\boldsymbol{E}\in\mathbb{R}^{m\times d}$ 都有唯一解，当且仅当对 $\boldsymbol{G}$ 的任一特征值 λ 与 $\boldsymbol{H}$ 的任一特征值 μ，都有 $\lambda\mu\neq 1$。特别地，方程 (16.6)对每个 $\boldsymbol{Q}$ 唯一可解，当且仅当 $\boldsymbol{A}$ 在复数域中的任意两个特征值 λ,λ'（可以是同一个）满足 $\lambda\lambda'\neq 1$；此时若 $\boldsymbol{Q}$ 对称，则解对称。

证明　与定理 16.1的证明一样，向量化后的系数矩阵是实矩阵，唯一可解等价于它的行列式非零，所以只需在复数域中判断齐次方程 $\boldsymbol{Y}=\boldsymbol{G}^{\top}\boldsymbol{Y}\boldsymbol{H}$ 是否只有零解。

必要性。设 $\lambda\mu=1$。$\boldsymbol{G}^{\top}$ 与 $\boldsymbol{G}$、$\boldsymbol{H}^{\top}$ 与 $\boldsymbol{H}$ 的特征值分别相同，可取非零向量 $\boldsymbol{w},\boldsymbol{v}$ 使 $\boldsymbol{G}^{\top}\boldsymbol{w}=\lambda\boldsymbol{w}$、$\boldsymbol{H}^{\top}\boldsymbol{v}=\mu\boldsymbol{v}$。令 $\boldsymbol{Y}=\boldsymbol{w}\boldsymbol{v}^{\top}\neq\boldsymbol{0}$，则 $\boldsymbol{Y}\boldsymbol{H}=\boldsymbol{w}(\boldsymbol{H}^{\top}\boldsymbol{v})^{\top}=\mu\boldsymbol{Y}$，于是 $\boldsymbol{G}^{\top}\boldsymbol{Y}\boldsymbol{H}=\lambda\mu\boldsymbol{Y}=\boldsymbol{Y}$，齐次方程有非零解。

充分性要用复数域中的三角化。把定理 4.26证明中的归纳搬到复数域：复方阵总有复特征向量，每一步取它张成的一维不变子空间，用标准正交基扩充成酉矩阵（第 3.6节），就得到 $\boldsymbol{G}=\boldsymbol{W}_1\boldsymbol{R}_1\boldsymbol{W}_1^{*}$、$\boldsymbol{H}=\boldsymbol{W}_2\boldsymbol{R}_2\boldsymbol{W}_2^{*}$，其中 $\boldsymbol{W}_1,\boldsymbol{W}_2$ 为酉矩阵，$\boldsymbol{R}_1,\boldsymbol{R}_2$ 上三角，对角元分别是 $\boldsymbol{G}$、$\boldsymbol{H}$ 的特征值。$\boldsymbol{G}$ 是实矩阵，$\boldsymbol{G}^{\top}=\boldsymbol{G}^{*}=\boldsymbol{W}_1\boldsymbol{R}_1^{*}\boldsymbol{W}_1^{*}$。

设 $\boldsymbol{Y}=\boldsymbol{G}^{\top}\boldsymbol{Y}\boldsymbol{H}$，令 $\boldsymbol{Z}=\boldsymbol{W}_1^{*}\boldsymbol{Y}\boldsymbol{W}_2$，则 $\boldsymbol{Z}=\boldsymbol{R}_1^{*}\boldsymbol{Z}\boldsymbol{R}_2$。$\boldsymbol{R}_1^{*}$ 是下三角矩阵，其 (i,k) 元为 $\overline{(\boldsymbol{R}_1)_{k,i}}$，所以比较 (i,j) 元得

$$\bigl(1-\overline{(\boldsymbol{R}_1)_{i,i}}\,(\boldsymbol{R}_2)_{j,j}\bigr)z_{i,j}=\sum_{\substack{k\le i,\ \ell\le j\\(k,\ell)\neq(i,j)}}\overline{(\boldsymbol{R}_1)_{k,i}}\,z_{k,\ell}\,(\boldsymbol{R}_2)_{\ell,j}.$$

实矩阵的非实特征值成共轭对出现，所以 $\overline{(\boldsymbol{R}_1)_{i,i}}$ 仍是 $\boldsymbol{G}$ 的特征值，左边系数按假设非零。右端各项满足 $k+\ell<i+j$。对 $i+j$ 归纳：$i+j=2$ 时右端为空，$z_{1,1}=0$；若下标和较小的元素都为零，右端为零，于是 $z_{i,j}=0$。所以 $\boldsymbol{Z}=\boldsymbol{0}$，$\boldsymbol{Y}=\boldsymbol{0}$。

取 $\boldsymbol{G}=\boldsymbol{H}=\boldsymbol{A}$ 即得关于方程 (16.6)的结论。若 $\boldsymbol{Q}$ 对称，对方程转置，由 $(\boldsymbol{A}^{\top}\boldsymbol{X}\boldsymbol{A})^{\top}=\boldsymbol{A}^{\top}\boldsymbol{X}^{\top}\boldsymbol{A}$ 知 $\boldsymbol{X}^{\top}$ 也是解，由唯一性 $\boldsymbol{X}^{\top}=\boldsymbol{X}$。 ■

下面最常用的是 $\rho(\boldsymbol{A})<1$ 的情形。此时任意两个特征值满足 $|\lambda\lambda'|<1$，条件自然成立；唯一性还可以不经三角化，直接由矩阵幂的衰减证明。后面的级数论证用的就是这一直接证明。

引理 16.8　谱半径小于一时的唯一性　若谱半径 $\rho(\boldsymbol{A})<1$，则方程 (16.6)至多有一个解；若 $\boldsymbol{Q}$ 对称且解存在，则解对称。

证明　两个解之差 $\boldsymbol{X}$ 满足 $\boldsymbol{X}=\boldsymbol{A}^{\top}\boldsymbol{X}\boldsymbol{A}$。反复代入得 $\boldsymbol{X}=(\boldsymbol{A}^{\top})^{k}\boldsymbol{X}\boldsymbol{A}^{k}$，于是 $\|\boldsymbol{X}\|_2\le\|\boldsymbol{A}^{k}\|_2^{2}\|\boldsymbol{X}\|_2$；由定理 8.6，$\boldsymbol{A}^{k}\to\boldsymbol{0}$，故 $\boldsymbol{X}=\boldsymbol{0}$。若 $\boldsymbol{Q}$ 对称，对方程转置可知 $\boldsymbol{X}^{\top}$ 也是解，由唯一性 $\boldsymbol{X}^{\top}=\boldsymbol{X}$。 ■

级数 $\sum_{k}(\boldsymbol{A}^{\top})^{k}\boldsymbol{Q}\boldsymbol{A}^{k}$ 的收敛与正定性在第 16.2.3节建立。

连续型方程对应状态随时间连续变化的情形。若状态按 $\dot{\boldsymbol{x}} = \boldsymbol{A}\boldsymbol{x}$ 演化（这类方程的解理论在后续卷中建立），由乘积的求导法则，二次量 $\boldsymbol{x}^{\top}\boldsymbol{X}\boldsymbol{x}$ 的变化率为 $\boldsymbol{x}^{\top}(\boldsymbol{A}^{\top}\boldsymbol{X} + \boldsymbol{X}\boldsymbol{A})\boldsymbol{x}$。要求它恰好等于 $-\boldsymbol{x}^{\top}\boldsymbol{Q}\boldsymbol{x}$，就得到连续型 Lyapunov 方程

$$\boldsymbol{A}^{\top}\boldsymbol{X} + \boldsymbol{X}\boldsymbol{A} = -\boldsymbol{Q}. \tag{16.7}$$

这一段只用来说明方程的来历，本章不使用连续演化的任何结论。在代数上，它是 Sylvester 方程取左系数 $\boldsymbol{A}^{\top}$、右系数 $\boldsymbol{A}$、右端 $-\boldsymbol{Q}$ 的特例。$\boldsymbol{A}^{\top}$ 与 $\boldsymbol{A}$ 的特征值相同，所以 Sylvester 方程的谱条件在这里变成 $\boldsymbol{A}$ 自身特征值两两之和的条件。

定理 16.9　连续型 Lyapunov 方程的唯一可解性　设 $\boldsymbol{A} \in \mathbb{R}^{d\times d}$。方程 (16.7)对每个 $\boldsymbol{Q} \in \mathbb{R}^{d\times d}$ 都有唯一解，当且仅当对 $\boldsymbol{A}$ 在复数域中的任意两个特征值 λ, λ'（可以是同一个），都有 $\lambda + \lambda' \neq 0$。此时若 $\boldsymbol{Q}$ 对称，则解 $\boldsymbol{X}$ 也对称。

证明　在定理 16.1中取左系数 $\boldsymbol{A}^{\top}$、右系数 $\boldsymbol{A}$。$\operatorname{spec}(\boldsymbol{A}^{\top}) = \operatorname{spec}(\boldsymbol{A})$，$\operatorname{spec}(-\boldsymbol{A}) = \{-\lambda : \lambda \in \operatorname{spec}(\boldsymbol{A})\}$，所以条件 (16.3)恰好是任意两个特征值之和不为零，由该定理得第一部分。若 $\boldsymbol{Q}$ 对称，对方程转置得 $\boldsymbol{X}^{\top}\boldsymbol{A} + \boldsymbol{A}^{\top}\boldsymbol{X}^{\top} = -\boldsymbol{Q}$，$\boldsymbol{X}^{\top}$ 也是解，由唯一性 $\boldsymbol{X}^{\top} = \boldsymbol{X}$。 ∎

$\boldsymbol{A}$ 的特征值实部全负时，任意两个之和的实部为负，唯一性成立。但这只是充分条件：例如 $\boldsymbol{A} = \operatorname{diag}(1, 2)$ 的谱和 $2, 3, 4$ 都不为零，方程同样唯一可解。离散型的对应情形是：$\rho(\boldsymbol{A}) < 1$ 是 $\lambda\lambda' \neq 1$ 的充分条件而非必要条件，$\boldsymbol{A} = \operatorname{diag}(2, 3)$ 的各个乘积 $4, 6, 9$ 都不等于 1。两种条件的强化形式（实部全负、谱半径小于一）在第 16.2.3节决定解是否正定。

16.2.2　对称解的计算与检验

两类方程都可以看成 Sylvester 型方程，直接套用第 16.1.3节的算法也能求解。但那样做要对 $\boldsymbol{A}$ 与 $\boldsymbol{A}^{\top}$ 分别分解，也没有利用解的对称性。本节只作一次 Schur 分解，并只求解的上三角部分。

主要思想：一次 Schur 变换　对 $\boldsymbol{A}$ 作实 Schur 分解 $\boldsymbol{A} = \boldsymbol{U}\boldsymbol{T}\boldsymbol{U}^{\top}$，则 $\boldsymbol{A}^{\top} = \boldsymbol{U}\boldsymbol{T}^{\top}\boldsymbol{U}^{\top}$。令 $\boldsymbol{Y} = \boldsymbol{U}^{\top}\boldsymbol{X}\boldsymbol{U}$、$\boldsymbol{D} = \boldsymbol{U}^{\top}\boldsymbol{Q}\boldsymbol{U}$，$\boldsymbol{D}$ 仍对称。把分解代入方程 (16.7)与 (16.6)，左乘 $\boldsymbol{U}^{\top}$、右乘 $\boldsymbol{U}$，分别得

$$\boldsymbol{T}^{\top}\boldsymbol{Y} + \boldsymbol{Y}\boldsymbol{T} = -\boldsymbol{D}, \qquad \boldsymbol{Y} - \boldsymbol{T}^{\top}\boldsymbol{Y}\boldsymbol{T} = \boldsymbol{D}.$$

$\boldsymbol{X}$ 对称当且仅当 $\boldsymbol{Y}$ 对称，唯一可解时 $\boldsymbol{Y}$ 确实对称，所以只需求 $i \le j$ 的元素 $y_{i,j}$，下三角部分由 $y_{j,i} = y_{i,j}$ 填入。下面先设 $\boldsymbol{T}$ 上三角。

主要思想：连续型的逐元素递推 $\boldsymbol{T}^{\top}$ 是下三角矩阵，$(\boldsymbol{T}^{\top}\boldsymbol{Y})_{i,j}=\sum_{k\le i}t_{k,i}y_{k,j}$；$(\boldsymbol{Y}\boldsymbol{T})_{i,j}=\sum_{k\le j}y_{i,k}t_{k,j}$。把含 $y_{i,j}$ 的两项留在左边，得

$$(t_{i,i}+t_{j,j})\,y_{i,j}=-d_{i,j}-\sum_{k<i}t_{k,i}y_{k,j}-\sum_{k<j}y_{i,k}t_{k,j}. \tag{16.8}$$

按列 $j=1,\dots,d$ 从左向右，每列内按行 $i=1,\dots,j$ 从上到对角元计算。检查右端用到的元素：$y_{k,j}$（$k<i$）在同一列更靠上，已经求出；$y_{i,k}$（$k<j$）按对称性改写为上三角位置后，所在列号不超过 j，列号等于 j 时只可能是 $i=j$、行号 $k<j$，也已求出。除数 $t_{i,i}+t_{j,j}$ 是 $\boldsymbol{A}$ 的两个特征值之和，由定理 16.9的条件不为零。

这一次序不能照搬第 16.1.3节。那里左系数 $\boldsymbol{T}$ 是上三角，依赖指向同列更靠下的元素，每列从下向上；这里左系数换成下三角的 $\boldsymbol{T}^{\top}$，依赖指向同列更靠上的元素，所以每列从上向下。

主要思想：离散型的逐元素递推 离散型中

$$(\boldsymbol{T}^{\top}\boldsymbol{Y}\boldsymbol{T})_{i,j}=\sum_{k\le i,\ \ell\le j}t_{k,i}\,y_{k,\ell}\,t_{\ell,j},$$

其中只有 $(k,\ell)=(i,j)$ 一项含 $y_{i,j}$。把它移到左边，得

$$(1-t_{i,i}t_{j,j})\,y_{i,j}=d_{i,j}+\sum_{\substack{k\le i,\ \ell\le j\\(k,\ell)\neq(i,j)}}t_{k,i}\,y_{k,\ell}\,t_{\ell,j}. \tag{16.9}$$

采用与连续型相同的次序。右端的 $y_{k,\ell}$ 满足 $k\le i\le j$、$\ell\le j$；按对称性写成上三角位置后，所在列号 $\max(k,\ell)\le j$。列号小于 j 的元素在前面的列中已经求出；列号等于 j 时，要么 $\ell=j$、$k<i$，要么 $k=i=j$、$\ell<j$，两种情形都是当前列更靠上的元素。所以同一列序只读取已求元素。除数 $1-t_{i,i}t_{j,j}$ 由定理 16.7的条件不为零。

主要思想：整列形式与对称性 若不利用对称性、把整列 $\boldsymbol{y}_j$ 作为未知量，两类方程按列分别写成

$$(\boldsymbol{T}^{\top}+t_{j,j}\boldsymbol{I})\boldsymbol{y}_j=-\boldsymbol{d}_j-\sum_{\ell<j}t_{\ell,j}\boldsymbol{y}_{\ell},\qquad(\boldsymbol{I}-t_{j,j}\boldsymbol{T}^{\top})\boldsymbol{y}_j=\boldsymbol{d}_j+\boldsymbol{T}^{\top}\sum_{\ell<j}t_{\ell,j}\boldsymbol{y}_{\ell}.$$

右端只用到更靠左的列，系数是下三角矩阵，每列从上到下前代。这样要求全部 d^2 个元素。若只求上三角部分，右端中左边各列的下三角元素 $y_{i,\ell}$（$i>\ell$）就要取为 $y_{\ell,i}$，其中 $i=j$ 的元素恰好位于当前列，是正在求解的未知量。所以利用对称性时应按式 (16.8)与 (16.9)逐元素推进，未知量从 d^2 个减为 $d(d+1)/2$ 个。

主要思想：二阶块与局部算子 $\boldsymbol{T}$ 含 2×2 对角块时，把相应的行和列成对处理。记 $\boldsymbol{T}$ 的对角块为 $\boldsymbol{T}_{I,I}$，按块写出的两类局部方程为

$$\boldsymbol{T}_{I,I}^{\top}\boldsymbol{Y}_{I,J}+\boldsymbol{Y}_{I,J}\boldsymbol{T}_{J,J}=-\boldsymbol{D}_{I,J}-\sum_{K<I}\boldsymbol{T}_{K,I}^{\top}\boldsymbol{Y}_{K,J}-\sum_{K<J}\boldsymbol{Y}_{I,K}\boldsymbol{T}_{K,J},$$

$$\boldsymbol{Y}_{I,J}-\boldsymbol{T}_{I,I}^{\top}\boldsymbol{Y}_{I,J}\boldsymbol{T}_{J,J}=\boldsymbol{D}_{I,J}+\sum_{\substack{K\le I,\,L\le J\\(K,L)\neq(I,J)}}\boldsymbol{T}_{K,I}^{\top}\boldsymbol{Y}_{K,L}\boldsymbol{T}_{L,J}.$$

每个局部方程至多含四个未知数，向量化后直接消元。对角块 $I=J$ 时 $\boldsymbol{Y}_{I,I}$ 对称，只需存三个未知量。局部算子的可逆性分别由定理 16.1（左系数 $\boldsymbol{T}_{I,I}^{\top}$、右系数 $\boldsymbol{T}_{J,J}$）与定理 16.7（$\boldsymbol{G}=\boldsymbol{T}_{I,I}$、$\boldsymbol{H}=\boldsymbol{T}_{J,J}$）给出：两块的特征值都是 $\boldsymbol{A}$ 的特征值，所以标量情形的“分母非零”推广为“局部算子可逆”。与 Sylvester 方程一样，局部系数接近奇异时实现中应保留缩放因子并给出条件警告。

算法实现 算法依次执行以下步骤。

1. 检查 $\boldsymbol{Q}$ 是否对称；不对称的输入不属于本节的问题。
2. 计算 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{T}\boldsymbol{U}^{\top}$ 与 $\boldsymbol{D}=\boldsymbol{U}^{\top}\boldsymbol{Q}\boldsymbol{U}$。
3. 按块列从左到右、每块列从上到对角块的次序，累计已知项，解局部方程，并把 $\boldsymbol{Y}_{I,J}^{\top}$ 镜像填入 $\boldsymbol{Y}_{J,I}$。
4. 恢复 $\boldsymbol{X}=\boldsymbol{U}\boldsymbol{Y}\boldsymbol{U}^{\top}$，在原坐标中检查残差、对称性，以及问题要求的正定性。

第四步必须在原方程中进行，只检查变换后的小系统是不够的。也不能把算出的非对称误差强行平均后就宣布成功，对称化与残差检验回答的是不同的问题（见本节末的检验）。

示例 16.10　连续型方程的逐元素递推 取 $\boldsymbol{A}=\left[\begin{smallmatrix}-1 & 1\\ 0 & -2\end{smallmatrix}\right]$、$\boldsymbol{Q}=\boldsymbol{I}$。$\boldsymbol{A}$ 已是上三角，取 $\boldsymbol{U}=\boldsymbol{I}$、$\boldsymbol{T}=\boldsymbol{A}$、$\boldsymbol{D}=\boldsymbol{I}$；特征值 $-1,-2$ 两两之和 $-2,-3,-4$ 都不为零。记 $\boldsymbol{X}=\left[\begin{smallmatrix}p & q\\ q & r\end{smallmatrix}\right]$，按式 (16.8)依次计算：

$$\begin{aligned}
&(1,1):\quad -2p=-1, && p=\tfrac{1}{2},\\
&(1,2):\quad -3q=-p\,t_{1,2}=-p, && q=\tfrac{1}{6},\\
&(2,2):\quad -4r=-1-t_{1,2}q-q\,t_{1,2}=-1-2q, && r=\tfrac{1}{3}.
\end{aligned}$$

第二步就是 $p-3q=0$，第三步就是 $2q-4r=-1$。代回原方程：$\boldsymbol{A}^{\top}\boldsymbol{X}+\boldsymbol{X}\boldsymbol{A}=\left[\begin{smallmatrix}-2p & p-3q\\ p-3q & 2q-4r\end{smallmatrix}\right]=-\boldsymbol{I}$。解对称，且 $p=\tfrac{1}{2}>0$、$\det\boldsymbol{X}=\tfrac{1}{6}-\tfrac{1}{36}=\tfrac{5}{36}>0$，所以 $\boldsymbol{X}\succ 0$。

示例 16.11　离散型方程的逐元素递推　取 $\boldsymbol{A}=\left[\begin{smallmatrix}1/2 & 1/4\\ 0 & 1/2\end{smallmatrix}\right]$、$\boldsymbol{Q}=\boldsymbol{I}$，同样取 $\boldsymbol{U}=\boldsymbol{I}$、$\boldsymbol{T}=\boldsymbol{A}$。特征值都是 $1/2$，乘积 $1/4\neq 1$，分母 $1-t_{i,i}t_{j,j}=3/4$。记 $\boldsymbol{X}=\left[\begin{smallmatrix}p & q\\ q & r\end{smallmatrix}\right]$，按式 (16.9)依次计算。$(1,1)$ 元的右端没有其他项，$\frac{3}{4}p=1$，$p=\frac{4}{3}$。$(1,2)$ 元的右端只有 $(k,\ell)=(1,1)$ 一项 $t_{1,1}\,p\,t_{1,2}=p/8$，于是 $\frac{3}{4}q=p/8$，$q=\frac{2}{9}$。$(2,2)$ 元的右端有三项：

$$t_{1,2}\,p\,t_{1,2}=\frac{p}{16},\qquad t_{1,2}\,q\,t_{2,2}=\frac{q}{8},\qquad t_{2,2}\,q\,t_{1,2}=\frac{q}{8},$$

于是 $\frac{3}{4}r=1+\frac{p}{16}+\frac{q}{4}=\frac{41}{36}$，$r=\frac{41}{27}$。

代回全部元素：$\boldsymbol{A}^{\top}\boldsymbol{X}\boldsymbol{A}$ 的 $(1,1)$ 元为 $p/4=\frac{1}{3}$，$(1,2)$ 元为 $p/8+q/4=\frac{1}{6}+\frac{1}{18}=\frac{2}{9}$，$(2,2)$ 元为 $p/16+q/4+r/4=\frac{1}{12}+\frac{1}{18}+\frac{41}{108}=\frac{14}{27}$。于是 $\boldsymbol{X}-\boldsymbol{A}^{\top}\boldsymbol{X}\boldsymbol{A}$ 的三个元素为 $\frac{4}{3}-\frac{1}{3}=1$、$\frac{2}{9}-\frac{2}{9}=0$、$\frac{41}{27}-\frac{14}{27}=1$，等于 $\boldsymbol{I}$。又 $p>0$、$\det\boldsymbol{X}=\frac{4}{3}\cdot\frac{41}{27}-\frac{4}{81}=\frac{160}{81}>0$，所以 $\boldsymbol{X}\succ 0$。

下面的例子中 $\boldsymbol{A}$ 有零特征值，还可以用累计量直接核对结果。

示例 16.12　离散型方程的递推与累计量　取上三角矩阵 $\boldsymbol{A}=\left[\begin{smallmatrix}1/2 & 1\\ 0 & 0\end{smallmatrix}\right]$ 与 $\boldsymbol{Q}=\boldsymbol{I}$，此时可取 $\boldsymbol{U}=\boldsymbol{I}$、$\boldsymbol{T}=\boldsymbol{A}$、$\boldsymbol{D}=\boldsymbol{I}$。特征值为 $1/2,0$，两两乘积 $1/4,0,0$ 都不等于 1。按式 (16.9)：$(1,1)$ 元满足 $(1-\frac{1}{4})y_{1,1}=1$，得 $y_{1,1}=\frac{4}{3}$；$(1,2)$ 元的分母为 $1-t_{1,1}t_{2,2}=1$，右端为 $d_{1,2}+t_{1,1}y_{1,1}t_{1,2}=0+\frac{1}{2}\cdot\frac{4}{3}\cdot 1$，得 $y_{1,2}=\frac{2}{3}$；$(2,2)$ 元的分母为 1，右端三项中含 $t_{2,2}=0$ 的两项为零，只剩 $t_{1,2}y_{1,1}t_{1,2}=\frac{4}{3}$，得 $y_{2,2}=1+\frac{4}{3}=\frac{7}{3}$。于是

$$\boldsymbol{X}=\begin{bmatrix}4/3 & 2/3\\ 2/3 & 7/3\end{bmatrix},\qquad \boldsymbol{A}^{\top}\boldsymbol{X}\boldsymbol{A}=\begin{bmatrix}1/3 & 2/3\\ 2/3 & 4/3\end{bmatrix},$$

两者之差为 $\boldsymbol{I}$，残差为零。这里 $\rho(\boldsymbol{A})=1/2<1$，也可以从累计量核对：$\boldsymbol{x}_0=(0,1)^{\top}$ 时 $\boldsymbol{x}_1=(1,0)^{\top}$，此后每步减半，$\sum_k\|\boldsymbol{x}_k\|_2^2=1+1+\frac{1}{4}+\frac{1}{16}+\cdots=\frac{7}{3}=x_{2,2}$。

前三个例子的 $\boldsymbol{A}$ 已是上三角。下面的例子需要先作 Schur 变换。

示例 16.13　连续型方程的 Schur 求解　取

$$\boldsymbol{A}=\begin{bmatrix}0 & 3\\ -1 & -4\end{bmatrix},\qquad \boldsymbol{Q}=\begin{bmatrix}2 & 0\\ 0 & 10\end{bmatrix}.$$

$\boldsymbol{A}$ 的特征值为 $-3,-1$，谱和 $-6,-4,-2$ 都不为零。由 $\boldsymbol{A}(1,-1)^{\top}=-3(1,-1)^{\top}$，取 $\boldsymbol{U}=\frac{1}{\sqrt{2}}\left[\begin{smallmatrix}1&1\\-1&1\end{smallmatrix}\right]$，得

$$\boldsymbol{T}=\boldsymbol{U}^{\top}\boldsymbol{A}\boldsymbol{U}=\begin{bmatrix}-3&4\\0&-1\end{bmatrix},\qquad \boldsymbol{D}=\boldsymbol{U}^{\top}\boldsymbol{Q}\boldsymbol{U}=\begin{bmatrix}6&-4\\-4&6\end{bmatrix}.$$

按式 (16.8)依次计算：$(1,1)$ 元 $-6y_{1,1}=-6$，得 $y_{1,1}=1$；$(1,2)$ 元 $-4y_{1,2}=-d_{1,2}-y_{1,1}t_{1,2}=4-4$，得 $y_{1,2}=0$；$(2,2)$ 元 $-2y_{2,2}=-6-t_{1,2}y_{1,2}-y_{2,1}t_{1,2}=-6$，得 $y_{2,2}=3$。于是 $\boldsymbol{Y}=\operatorname{diag}(1,3)$，变回原坐标得

$$\boldsymbol{X}=\boldsymbol{U}\boldsymbol{Y}\boldsymbol{U}^{\top}=\begin{bmatrix}2&1\\1&2\end{bmatrix}.$$

核验：$\boldsymbol{A}^{\top}\boldsymbol{X}=\left[\begin{smallmatrix}-1&-2\\2&-5\end{smallmatrix}\right]$，加上它的转置 $\boldsymbol{X}\boldsymbol{A}$ 得 $\operatorname{diag}(-2,-10)=-\boldsymbol{Q}$，原方程残差为零，$\boldsymbol{X}$ 对称。

算法分析：对称性、残差与正定性检验 对需要正定解的应用，还要另外检查对称性与正定性，并在浮点计算中把三项检验放在一起解释。算出的 $\boldsymbol{X}$ 可能有舍入量级的微小不对称。对称化只消除这一偏差，不能说明方程解对了；后者要看原方程的相对残差是否在机器精度的若干倍以内。

正定性可以用 Cholesky 分解（第 10.2节）检验，但浮点中分解成功只说明一个与 $\boldsymbol{X}$ 相差舍入量级的对称矩阵正定（第 14.1.2节）。只有当 $\lambda_{\min}(\boldsymbol{X})$ 明显大于这一舍入量级时，分解成败才能判定 $\boldsymbol{X}$ 本身是否正定；否则还应结合残差容差和问题本身是否保证正定（第 16.2.3节）来判断。示例 16.13中 $\boldsymbol{X}$ 的 Cholesky 因子对角元为 $\sqrt{2}$ 与 $\sqrt{3/2}$，分解成功，$\boldsymbol{X}\succ 0$。

算法分析：计算代价 一次实 Schur 分解约需 $25d^3$ 次运算，变换右端与恢复解各约 $O(d^3)$ 次。连续型递推中每个元素的和式有 $O(d)$ 项，总量 $O(d^3)$。离散型的式 (16.9)含双重和，逐元素直接求和总量为 $O(d^4)$；实现时按列保存部分乘积（如 $\sum_{\ell<j}t_{\ell,j}\boldsymbol{y}_{\ell}$ 及其左乘 $\boldsymbol{T}^{\top}$ 的结果），可以把总量降到 $O(d^3)$。所以两类方程的总代价都由 $O(d^3)$ 主导，存储为 $O(d^2)$。

16.2.3 正定解的存在条件

上一节的算法在唯一可解时算出对称解，但不保证解正定。本节先回到离散累计：$\rho(\boldsymbol{A})<1$ 时，离散型方程的解就是第 16.2.1节累计量 $\boldsymbol{X}_N$ 的极限，正定性可以从级数逐项读出。

定理 16.14　离散型 Lyapunov 方程的级数解　设 $\rho(\boldsymbol{A})<1$，$\boldsymbol{Q}$ 对称。则级数

$$\boldsymbol{X}=\sum_{k=0}^{\infty}(\boldsymbol{A}^{\top})^{k}\boldsymbol{Q}\boldsymbol{A}^{k} \tag{16.10}$$

收敛，且是方程 (16.6)的唯一解。若 $\boldsymbol{Q}\succeq 0$，则 $\boldsymbol{X}\succeq 0$；若 $\boldsymbol{Q}\succ 0$，则 $\boldsymbol{X}\succ 0$。

证明　取 $r\in(\rho(\boldsymbol{A}),1)$。由引理 8.4，存在 C_r 使 $\|\boldsymbol{A}^{k}\|_2\le C_r r^{k}$，所以第 k 项的范数不超过 $\|\boldsymbol{Q}\|_2 C_r^2 r^{2k}$。这是收敛几何级数的通项，由定理 3.30，级数绝对收敛，记部分和为 $\boldsymbol{X}_N$。

映射 $\mathcal{M}(\boldsymbol{Y})=\boldsymbol{A}^{\top}\boldsymbol{Y}\boldsymbol{A}$ 满足 $\|\mathcal{M}(\boldsymbol{Y})\|_2\le\|\boldsymbol{A}\|_2^2\|\boldsymbol{Y}\|_2$，是连续的线性映射，故 $\mathcal{M}(\boldsymbol{X}_N)\to\mathcal{M}(\boldsymbol{X})$。逐项作用后移项相消，

$$\boldsymbol{X}_N-\mathcal{M}(\boldsymbol{X}_N)=\boldsymbol{Q}-(\boldsymbol{A}^{\top})^{N+1}\boldsymbol{Q}\boldsymbol{A}^{N+1},$$

右端末项的范数不超过 $\|\boldsymbol{Q}\|_2 C_r^2 r^{2(N+1)}\to 0$。令 $N\to\infty$ 得 $\boldsymbol{X}-\boldsymbol{A}^{\top}\boldsymbol{X}\boldsymbol{A}=\boldsymbol{Q}$，唯一性由引理 16.8给出。

对任意 $\boldsymbol{x}$，$\boldsymbol{x}^{\top}(\boldsymbol{A}^{\top})^{k}\boldsymbol{Q}\boldsymbol{A}^{k}\boldsymbol{x}=(\boldsymbol{A}^{k}\boldsymbol{x})^{\top}\boldsymbol{Q}(\boldsymbol{A}^{k}\boldsymbol{x})$，所以 $\boldsymbol{Q}\succeq 0$ 时各项都半正定，$\boldsymbol{X}\succeq 0$。$\boldsymbol{Q}\succ 0$ 时，对 $\boldsymbol{x}\neq\boldsymbol{0}$，首项 $\boldsymbol{x}^{\top}\boldsymbol{Q}\boldsymbol{x}>0$ 而其余项非负，故 $\boldsymbol{X}\succ 0$。 ■

标量情形可以直接核对符号和分母。$d=1$、$|a|<1$ 时，级数为 $x=\sum_{k} q\,a^{2k}=q/(1-a^2)$，代入方程得 $x-a^2x=q$；分母 $1-a^2$ 正是唯一性条件中的 $1-\lambda\lambda$，$q>0$ 时 $x>0$。

半正定右端　实际问题中常只计量状态的一部分，例如 $\boldsymbol{Q}=\boldsymbol{c}\boldsymbol{c}^{\top}$ 只记录一个线性读数 $\boldsymbol{c}^{\top}\boldsymbol{x}_k$ 的平方，这时 $\boldsymbol{Q}$ 奇异。定理 16.14只保证 $\boldsymbol{X}\succeq 0$。$\boldsymbol{X}$ 是否正定，取决于是否存在一个非零初始方向，沿它出发的整条轨迹始终不被累计量察觉。

定理 16.15　半正定右端的正定条件　设 $\rho(\boldsymbol{A})<1$，$\boldsymbol{Q}\succeq 0$，$\boldsymbol{X}$ 为级数 (16.10)给出的解。对 $\boldsymbol{x}\in\mathbb{R}^{d}$，$\boldsymbol{x}^{\top}\boldsymbol{X}\boldsymbol{x}=0$ 当且仅当 $\boldsymbol{Q}\boldsymbol{A}^{k}\boldsymbol{x}=\boldsymbol{0}$ 对 $k=0,1,\dots,d-1$ 都成立。因此 $\boldsymbol{X}\succ 0$，当且仅当

$$\begin{bmatrix}\boldsymbol{Q}\\ \boldsymbol{Q}\boldsymbol{A}\\ \vdots\\ \boldsymbol{Q}\boldsymbol{A}^{d-1}\end{bmatrix}$$

的零空间只含零向量，即它的秩为 d。

证明 由级数，$\boldsymbol{x}^{\top}\boldsymbol{X}\boldsymbol{x}=\sum_{k\ge 0}(\boldsymbol{A}^{k}\boldsymbol{x})^{\top}\boldsymbol{Q}(\boldsymbol{A}^{k}\boldsymbol{x})$，各项非负，所以它为零当且仅当每一项为零。对半正定的 $\boldsymbol{Q}$，$\boldsymbol{v}^{\top}\boldsymbol{Q}\boldsymbol{v}=0$ 等价于 $\boldsymbol{Q}\boldsymbol{v}=\boldsymbol{0}$：写 $\boldsymbol{Q}=\boldsymbol{L}\boldsymbol{L}^{\top}$（例如取谱分解的平方根），$\boldsymbol{v}^{\top}\boldsymbol{Q}\boldsymbol{v}=\|\boldsymbol{L}^{\top}\boldsymbol{v}\|_2^2=0$ 推出 $\boldsymbol{L}^{\top}\boldsymbol{v}=\boldsymbol{0}$，从而 $\boldsymbol{Q}\boldsymbol{v}=\boldsymbol{0}$；反向显然。于是 $\boldsymbol{x}^{\top}\boldsymbol{X}\boldsymbol{x}=0$ 当且仅当 $\boldsymbol{Q}\boldsymbol{A}^{k}\boldsymbol{x}=\boldsymbol{0}$ 对所有 $k\ge 0$ 成立。

只需检查前 d 个 k：由 Cayley–Hamilton 定理 4.5，$\boldsymbol{A}^{d}$ 是 $\boldsymbol{I},\boldsymbol{A},\dots,\boldsymbol{A}^{d-1}$ 的线性组合；乘以 $\boldsymbol{A}$ 后归纳可知，每个 $\boldsymbol{A}^{k}$（$k\ge d$）都是这些幂的线性组合。所以 $\boldsymbol{Q}\boldsymbol{A}^{k}\boldsymbol{x}=\boldsymbol{0}$ 对 $k<d$ 成立时，对所有 k 都成立。最后，$\boldsymbol{X}\succeq 0$，所以 $\boldsymbol{X}\succ 0$ 当且仅当 $\boldsymbol{x}^{\top}\boldsymbol{X}\boldsymbol{x}=0$ 只有零解，即上述堆叠矩阵的零空间只含零向量。 ■

这个条件在控制理论中称为可观测性：从读数序列 $\boldsymbol{Q}\boldsymbol{A}^{k}\boldsymbol{x}$ 能否区分初始状态。它只依赖 $\boldsymbol{A}$ 与 $\boldsymbol{Q}$ 的零空间结构，不依赖 $\boldsymbol{Q}$ 的具体大小。

示例 16.16　未被累计量察觉的方向 取 $\boldsymbol{A}=\left[\begin{smallmatrix}0&1\\0&0\end{smallmatrix}\right]$，$\rho(\boldsymbol{A})=0$，且 $\boldsymbol{A}^{2}=\boldsymbol{0}$，级数只有两项 $\boldsymbol{X}=\boldsymbol{Q}+\boldsymbol{A}^{\top}\boldsymbol{Q}\boldsymbol{A}$。$\boldsymbol{A}$ 把 $\boldsymbol{e}_2$ 送到 $\boldsymbol{e}_1$，把 $\boldsymbol{e}_1$ 送到零。

若 $\boldsymbol{Q}=\operatorname{diag}(1,0)$，只计量第一个坐标，则 $\boldsymbol{A}^{\top}\boldsymbol{Q}\boldsymbol{A}=\operatorname{diag}(0,1)$，$\boldsymbol{X}=\boldsymbol{I}\succ 0$。从 $\boldsymbol{e}_2$ 出发时第一步没有被计量，但下一步状态移到 $\boldsymbol{e}_1$ 上被察觉；按定理 16.15，$\boldsymbol{Q}\boldsymbol{x}=\boldsymbol{0}$ 给出 $x_1=0$，$\boldsymbol{Q}\boldsymbol{A}\boldsymbol{x}=(x_2,0)^{\top}=\boldsymbol{0}$ 又给出 $x_2=0$。

若 $\boldsymbol{Q}=\operatorname{diag}(0,1)$，只计量第二个坐标，则 $\boldsymbol{Q}\boldsymbol{A}=\boldsymbol{0}$，$\boldsymbol{X}=\boldsymbol{Q}=\operatorname{diag}(0,1)$ 奇异。方向 $\boldsymbol{e}_1$ 满足 $\boldsymbol{Q}\boldsymbol{e}_1=\boldsymbol{0}$、$\boldsymbol{Q}\boldsymbol{A}\boldsymbol{e}_1=\boldsymbol{0}$：从它出发的轨迹 $\boldsymbol{e}_1,\boldsymbol{0},\boldsymbol{0},\dots$ 始终不被计量，$\boldsymbol{e}_1^{\top}\boldsymbol{X}\boldsymbol{e}_1=0$。两种右端都只是秩一的半正定矩阵，结果却不同，区别在于未计量的方向是否会被 $\boldsymbol{A}$ 送进计量范围。

正定解给出的谱证书 前面由谱条件推出正定解。反过来，一个对称正定解本身就证明了谱条件，而且证明只用代数运算。这给上一节算法的输出提供了可检验的证书：残差小、Cholesky 分解在可靠的容差下成功，就同时检验了 $\boldsymbol{A}$ 的稳定性。

定理 16.17　正定解给出的谱证书　设 $Q\succ 0$，X 对称正定。

1. 若 $X-A^{\top}XA=Q$，则 A 的每个特征值满足 $|\lambda|<1$，即 $\rho(A)<1$。
2. 若 $A^{\top}X+XA=-Q$，则 A 的每个特征值的实部为负。

证明　设 $Av=\lambda v$，$v=a+\mathrm{i}b\neq 0$，a,b 为实向量。对实对称矩阵 M，$v^{*}Mv=a^{\top}Ma+b^{\top}Mb$，交叉项 $\mathrm{i}(a^{\top}Mb-b^{\top}Ma)$ 因对称而抵消；所以 $v^{*}Xv>0$、$v^{*}Qv>0$。A 是实矩阵，$v^{*}A^{\top}=(Av)^{*}=\bar{\lambda}v^{*}$。

离散型：$v^{*}A^{\top}XAv=\bar{\lambda}\lambda\,v^{*}Xv$，于是 $(1-|\lambda|^{2})\,v^{*}Xv=v^{*}Qv>0$，得 $|\lambda|<1$。

连续型：$v^{*}(A^{\top}X+XA)v=(\bar{\lambda}+\lambda)\,v^{*}Xv=2\operatorname{Re}\lambda\,v^{*}Xv$，它等于 $-v^{*}Qv<0$，得 $\operatorname{Re}\lambda<0$。 ■

示例 16.10与 16.11可以按这个证书反向读：两个 X 都对称正定、$Q=I$，分别证明了 $A=\left[\begin{smallmatrix}-1 & 1\\ 0 & -2\end{smallmatrix}\right]$ 的特征值实部为负、$A=\left[\begin{smallmatrix}1/2 & 1/4\\ 0 & 1/2\end{smallmatrix}\right]$ 的谱半径小于一；对这两个三角矩阵，这与直接读对角元的结论一致。

连续型的正定条件　连续型方程有与定理 16.14平行的结论：当 A 的特征值实部全负且 $Q\succ 0$ 时，唯一解 X 正定；$Q\succeq 0$ 时 $X\succeq 0$，并且与定理 16.15同样，$X\succ 0$ 当且仅当 $QA^{k}x=0$（$k=0,\dots,d-1$）只有零解。这里的唯一性由定理 16.9保证，正定性则需要另外的论证：把离散级数换成积分 $X=\int_{0}^{\infty}e^{tA^{\top}}Qe^{tA}\,\mathrm{d}t$，再验证积分收敛并满足方程。

这一论证要用矩阵指数 e^{tA} 的定义、导数以及特征值实部全负时的指数衰减，可参考卷六第 2 章“线性微分方程与系统”；积分表示与轨迹长期稳定性的完整推导在卷九第 1 章“动力系统与轨迹的长期行为”给出。本章只保留条件陈述和代数检验，求解算法也不以它为前提。

低维例子可以直接核验这一陈述。标量方程 $2ax=-q$ 在 $a<0$、$q>0$ 时给出 $x=q/(2|a|)>0$。示例 16.13中 A 的特征值为 $-3,-1$，$Q=\operatorname{diag}(2,10)\succ 0$，算出的 X 特征值为 $1,3$，确实正定；由定理 16.17，这个正定解反过来也证明了 A 的特征值实部为负。

16.3　本章小结

本章研究以矩阵为未知量、同时受左乘和右乘作用的方程。左右两种作用相加以后不能分别“除以”系数，但左边仍是矩阵空间上的线性算子；向量化把它写成 Kronecker 系数矩阵，说明一般线性方程的判据都适用，却不宜作为大规模计算的默认方法。

Sylvester 方程 $\boldsymbol{AX}+\boldsymbol{XB}=\boldsymbol{C}$ 对任意右端唯一可解，当且仅当 $\boldsymbol{A}$ 与 $-\boldsymbol{B}$ 没有公共特征值，这与两侧系数各自是否可逆无关。谱和为零时，对角情形清楚地显示出无解与多解两种退化。谱分离只回答唯一性，不回答敏感度：最小谱和接近零，或者特征基远离正交，都会放大数据误差。

计算上，Bartels–Stewart 算法用两个正交 Schur 变换把方程化为准三角形，按列从左到右、每列从下到上回代，二阶对角块只形成至多四个未知数的局部系统；正交变换保持 Frobenius 残差，所以原方程的残差可以直接检验整个流程。可对角化时换到特征基可以逐元素相除，但只有特征基接近正交时才可靠，一般情形仍用 Schur 路线。

Lyapunov 方程来自二次量的累计与变化。离散型 $\boldsymbol{X}-\boldsymbol{A}^{\top}\boldsymbol{X}\boldsymbol{A}=\boldsymbol{Q}$ 唯一可解的条件是特征值两两乘积不为一，连续型 $\boldsymbol{A}^{\top}\boldsymbol{X}+\boldsymbol{X}\boldsymbol{A}=-\boldsymbol{Q}$ 的条件是两两之和不为零；右端对称时解对称。在本章的写法下，两类方程都只需对 $\boldsymbol{A}$ 作一次 Schur 分解，再按列从左到右、每列从上到对角元逐元素递推，只求上三角部分。浮点结果要在原方程中检查残差，对称化和 Cholesky 分解分别回答对称性与正定性，不能互相代替。

正定性方面，$\rho(\boldsymbol{A})<1$ 时离散型的解就是绝对收敛的级数 $\sum_{k}(\boldsymbol{A}^{\top})^{k}\boldsymbol{Q}\boldsymbol{A}^{k}$：右端正定时解正定；右端只半正定时，解正定当且仅当不存在始终不被累计量察觉的非零初始方向，这一条件只需检查 $\boldsymbol{Q}\boldsymbol{A}^{k}\boldsymbol{x}=\boldsymbol{0}$（$k<d$）。反过来，对称正定解本身就是谱的证书：离散型给出 $\rho(\boldsymbol{A})<1$，连续型给出特征值实部全负，证明只用代数运算。

连续型方程在特征值实部全负时的正定解，本章只陈述了条件并用例子与谱证书作代数检验。它的一般证明要把离散级数换成矩阵指数的无穷积分，需要线性微分方程的解理论；这一积分表示连同它与轨迹长期稳定性的关系，在后续关于演化的理论中建立（见第 16.2.3节所指的位置）。

第四部分

多元微积分

Multivariate Calculus

阅读指引

前三部分研究的是线性作用：矩阵把一个向量映为另一个向量，误差按固定的倍数放大。本部分研究一般的多元映射，主线有两条：怎样描述它在一点附近的局部变化，以及怎样在区域、曲线和曲面上累计一个量。

前四章处理局部变化。多元函数微分章把函数看作位置上的标量场与向量场，用全微分统一预测所有方向的一阶变化，梯度、Jacobian 与 Hessian 分别记录标量输出、向量输出和二阶弯曲。矩阵函数的微分章以矩阵为自变量，给出乘积、求逆、行列式与对数行列式的微分公式和梯度。

隐函数与反函数章从方程出发，说明关于待解变量的 Jacobian 可逆时，方程在局部确定唯一的可微解。微分与扰动分析章把这三章的工具与谱分析部分的有限扰动界结合起来，研究指定方向的一阶响应、误差的局部放大倍数和线性预测的余项，并用于矩阵运算和隐式给定的谱分支。

后四章处理累计。区域积分章用分割和定义多维 Riemann 积分，再以累次积分、换元和参数积分计算它。路径积分章与曲面积分章分别按弧长和面积累计标量场，又按切向和法向累计向量场，得到功、环流与通量。积分定理章用散度与旋度描述局部的净流出与环流，再由 Green、Gauss 和 Stokes 公式把内部的导数累计与边界上的累计联系起来。

阅读时要分清几组容易混淆的对象：线性映射形式的微分与表示它的梯度或矩阵；指定方向的变化率、最坏方向的条件数与有限步长的余项；局部可逆与整体单射；按长度、面积等非负权重的累计与依赖方向或法向的累计。每个结论都带有定义域、光滑性、覆盖次数或定向的条件，使用时要逐项核对。

第 17 章

多元函数微分

一元微分研究输入改变一点时输出改变多少：导数 $f'(a)$ 是输出改变量与输入改变量之比的极限。许多量却同时依赖多个输入。平板上一点的温度由横、纵两个坐标决定，模型的损失由大量参数决定，流体的速度则在空间每一点给出一个向量。

以 $f(x,y)=x^2+xy+y^2$ 为例，输入是平面上的点 (x,y)，输出是一个实数。把 $z=f(x,y)$ 看成地形的高度，把 (x,y) 看成地图上的位置。从一点出发，可以向东走、向北走、斜着走，也可以沿一条弯曲的路线靠近。本章要回答的问题是：能否用一个线性映射统一预测所有这些走法下的输出变化；这个预测在什么条件下成立；它的弯曲部分又怎样决定一点附近的形状，例如驻点是谷底、山顶还是鞍点。

第 3章已经建立了收敛、极限与连续性，证明了有限维空间中范数等价、完备，并定义了算子范数与伴随；第 2章给出了线性映射、多线性映射与对偶空间。这些是本章的语言。本章新增的问题是：能否把精确变化 $f(\boldsymbol{a}+\boldsymbol{h})-f(\boldsymbol{a})$ 分成对 $\boldsymbol{h}$ 线性的一阶部分和更小的余项。函数连续、有限变化有界，都不保证这样的分解存在。

各节按“对象—一阶—向量输出—高阶”的次序展开。第一节把多元函数看作位置上的标量场与向量场，回顾极限与连续性的要点。第二节从坐标方向的变化率出发，判断偏导数与方向导数何时组成全微分，再用内积把全微分表示为梯度，并用中值估计控制有限变化。

第三节把输出扩大为向量，用 Jacobian 矩阵记录微分，用链式法则组合复杂映射，并用导数的算子范数估计向量增量。第四节把微分再用于梯度，得到 Hessian 和多元 Taylor 公式，并据此判断驻点附近的形状；判断定性时要用到第 4章的实对称谱分解。

本章只建立微分及其局部结论。以矩阵为自变量的微分在第 18章，由方程隐式确定的函数在第 19章；导数怎样控制误差放大、一阶预测在有限步长下还差多少，集中在第 20章。本章还沿用第 1章的向量、矩阵与行列式，以及一元微分的结论，可参考卷一第 6 章“一元函数的微分”。偏导数与局部线性近似的直观介绍可参考[1]。，严格的多元微分论证可参考[2]。

[1] G. Strang, E. J. Herman, *Calculus Volume 3*, OpenStax, 2016

[2] J. Lebl, *Basic Analysis II: Introduction to Real Analysis*, version 6.3, May 15, 2026, URL: https://www.jirka.org/ra/ (visited on 10/19/2026)

17.1　多元函数与场

微分和积分都要先说清研究的是什么函数。本部分最常见的情形是：空间中每个位置都带着一个可以测量的量。平板上每一点有温度，河水中每一点有流速，金属块中每一点有密度。这样的量随位置变化，输入是位置的坐标，输出是该位置上读出的量。

第 3.2.3节已经从极限的角度定义了多元标量函数与向量值映射。本节换一个角度，把它们看作空间位置上的属性：先按输出是一个数还是一个向量，区分标量场与向量场；再说明本部分的定义域、输出空间以及极限与连续性怎样理解。这些约定确定了后面各章微分与累计的对象。

17.1.1　标量场

温度计放在平板的不同位置，读数不同；把每个位置与它的读数配对，就得到一个函数。密度、压强、电势也都在每个位置给出一个实数。这类函数在每个位置只给出大小，不带方向。

> **定义 17.1　标量场**　设 $\Omega \subseteq \mathbb{R}^d$。映射 $f : \Omega \to \mathbb{R}$ 称为 Ω 上的标量场（scalar field）；它把每个位置 $\boldsymbol{x} \in \Omega$ 映为一个实数 $f(\boldsymbol{x})$。

作为映射，标量场就是定义 3.14中的多元标量函数。“场”这个名称只强调输入是空间位置、输出是该位置的属性。后面称它为多元函数还是标量场，取决于讨论的是一般的输入输出关系，还是位置上的物理量，数学内容相同。

以 $f(x,y) = x^2 + y^2$ 为例，它在每个位置给出到原点距离的平方。它有两种画法。第一种画法把函数值当作高度，得到三维空间中的曲面 $z = x^2 + y^2$，形状像一只碗。第二种画法留在输入平面里，画出等值曲线 $\{(x,y) : x^2 + y^2 = c\}$。

对这个函数，$c > 0$ 时等值曲线是半径为 $\sqrt{c}$ 的圆，$c = 0$ 时只剩原点，$c < 0$ 时是空集。取 $c = 1, 2, 3, 4$，半径依次为 $1, \sqrt{2} \approx 1.41, \sqrt{3} \approx 1.73, 2$，相邻两圈的间距越来越小。函数值每增加 1 所需走的距离越来越短，说明离原点越远，场值沿径向增长得越快。

这一观察还只是定性的。度量“沿某方向增长多快”需要导数：第 17.2.4节把它写成梯度，并说明梯度与等值曲线正交。

17.1.2　向量场

河水在每一点有流速，物体在重力场或电场中的每一点受力。这些量既有大小又有方向，并且与位置同处一个空间：流速可以画成从该点出发的箭头。

定义 17.2 向量场 设 $\Omega \subseteq \mathbb{R}^d$。映射 $\boldsymbol{F}:\Omega \to \mathbb{R}^d$ 称为 Ω 上的向量场（vector field）。按本书约定，$\boldsymbol{F}(\boldsymbol{x})$ 写成 $d\times 1$ 列矩阵 $(F_1(\boldsymbol{x}),\dots,F_d(\boldsymbol{x}))^{\top}$，每个分量 $F_i:\Omega\to\mathbb{R}$ 都是标量场。

向量场的输入是位置，输出是放在该位置的一个向量。例如 $\boldsymbol{F}(x,y)=(x,y)^{\top}$ 的箭头从原点向外，离原点越远越长；$\boldsymbol{F}(x,y)=(-y,x)^{\top}$ 的箭头与以原点为圆心的圆相切，按逆时针方向。第 22章用这两个场比较沿路径做的功。

向量场是向量值函数的特例。一般向量值函数 $F:\Omega\subseteq\mathbb{R}^d\to\mathbb{R}^m$ 的输出维数 m 可以与输入维数不同：参数曲线把一个参数映为空间中的点，神经网络的一层把输入向量映为另一维数的向量。向量场要求 $m=d$，输出向量才能画成输入空间中的箭头，也才能与路径的切向量或曲面的法向量作内积。

输出还可以是矩阵。若每个位置给出一个 $p\times q$ 矩阵，例如介质中每一点的应力矩阵，就得到矩阵值的场；它的每个元素仍是标量场。第 18章研究的则是另一种情形：输入本身是矩阵，例如 $\boldsymbol{X}\mapsto\boldsymbol{X}^{-1}$。判断一个映射属于哪一类时，要分别核对输入空间和输出空间，不能只看表达式里是否出现矩阵。

17.1.3 多元函数的极限与连续

标量场和向量场的极限与连续性已在第 3章建立，这里只回顾后面要用的结论，不重复证明。

极限用输入、输出空间的范数定义（定义 3.15）。$\lim_{\boldsymbol{x}\to\boldsymbol{a}}F(\boldsymbol{x})=\boldsymbol{L}$ 的意思是：只要输入进入以 $\boldsymbol{a}$ 为心的某个去心小球，输出与 $\boldsymbol{L}$ 的距离就小于给定误差，不论输入沿什么路线进入。连续性（定义 3.21）要求这个极限等于 $F(\boldsymbol{a})$。

对有限维的向量输出，这些判断可以逐分量进行：向量场或矩阵值的场在一点有极限或连续，当且仅当每个输出分量如此（定理 3.10）。逐分量分解的是输出。输入的多个坐标不能这样拆开，因为输入可以同时改变全部坐标、沿弯曲的路线趋近。

因此，沿路径检验只能用来否定极限。沿两条路径得到不同的极限值，联合极限就不存在：示例 3.16中的 $xy/(x^2+y^2)$ 沿 x 轴趋于 0，沿 $y=x$ 趋于 $1/2$。反过来，只检查若干条路径不能证明极限存在：示例 3.17中的 $x^2y/(x^4+y^2)$ 沿每条直线都趋于 0，沿抛物线 $y=x^2$ 却恒为 $1/2$。要证明极限存在，需要一个只依赖输入到基点距离的统一误差估计。

这个区别在微分中还会出现。方向导数是沿固定直线取的极限，全微分则要求误差对全部趋近方式统一受控；第 17.2.2节的反例与上面的抛物线例子结构相同。

最后约定定义域。讨论微分时，基点取在开集内部，从基点出发向任何方向走足够小的一步都不离开定义域；讨论积分时，累计范围通常是有界闭区域，这时只要求被积函数在区域上连续或满足相应的可积条件。

17.2　多元标量函数的一阶微分

上一节回顾的极限与连续只问函数值是否趋近，本节开始度量函数值变化的快慢。最直接的办法是沿一条直线把多元函数变成一元函数，再求一元导数，这样得到偏导数和方向导数。

偏导数和方向导数只描述固定直线上的变化。接下来要判断，这些方向信息何时组成一个对全部小扰动都有效的线性近似，即全微分。全微分是作用于输入扰动的线性泛函；借助对偶空间与内积，它可以由输入空间中的一个向量表示，这个向量就是梯度。最后沿线段使用一元中值定理，把梯度的大小转化为有限变化的界。

本节研究实值函数 $f:U\subseteq\mathbb{R}^d\to\mathbb{R}$，并要求 U 为开集。开集中每一点都有一个含于 U 的小球，从基点出发向任何方向走足够小的一步仍在定义域内，双侧差商因而都有意义。

17.2.1　偏导数与方向导数

固定除 x_j 以外的全部坐标，f 就变成只依赖 x_j 的一元函数，它的导数就是偏导数。

定义 17.3　偏导数　设 $\boldsymbol{a}\in U$，令 $\boldsymbol{e}_j$ 是第 j 个坐标为 1、其余为 0 的向量。若双侧极限

$$\partial_j f(\boldsymbol{a})=\frac{\partial f}{\partial x_j}(\boldsymbol{a})=\lim_{t\to 0}\frac{f(\boldsymbol{a}+t\boldsymbol{e}_j)-f(\boldsymbol{a})}{t}$$

存在且有限，就称它为 f 在 $\boldsymbol{a}$ 处关于 x_j 的**偏导数** (partial derivative)。

偏导数是只改变第 j 个坐标、其余坐标固定时的变化率。符号 ∂ 提醒我们，这里求的是一个坐标切片的导数。对二元函数，$\partial_x f(a,b)$ 是用竖直平面 $y=b$ 截曲面所得曲线在 $x=a$ 处的切线斜率；$\partial_y f(a,b)$ 则来自平面 $x=a$ 的截线。把 f 看成平板上的温度，$\partial_x f$ 就是向正东移动时温度每单位距离的变化。

计算偏导数时，把其余坐标当作常数，按一元函数求导即可。

示例 17.4 二次函数的偏导数 对 $f(x,y)=x^2+xy+y^2$，把 y 当作常数对 x 求导，得到 $f_x=2x+y$；把 x 当作常数对 y 求导，得到 $f_y=x+2y$。在 $(1,2)$ 处，两者分别为 4 和 5。这种“把其余坐标当常数”的算法与定义一致，可以拿第一个值来验证：

$$\frac{f(1+t,2)-f(1,2)}{t}=\frac{(1+t)^2+2(1+t)+4-7}{t}=4+t\longrightarrow 4.$$

偏导数还能预测沿坐标方向走一小步时函数值的增量。$f(1.01,2)=7.0401$，比 $f(1,2)=7$ 大约 $0.04=4\times 0.01$；$f(1,2.01)=7.0501$，大约大 5×0.01。两个预测都只差 10^{-4}，即步长的平方。

$f_x(1,2)=4$ 并不意味着朝任何方向走都以斜率 4 变化，每个偏导数只描述自己那条坐标切片。若同时走 $(0.01,0.01)$，则 $f(1.01,2.01)=7.0903$，增量约为 $0.04+0.05$，像是两个偏导数的贡献之和。这样相加并非总是成立；第 17.2.2节的可微性正是它成立的保证。

方向导数 沿坐标轴求导只考察了 d 个方向。让多个坐标按一个固定向量的比例共同移动，就得到另一条直线上的一元切片，它的导数称为方向导数。

定义 17.5 方向导数 给定向量 $\boldsymbol{v}\in\mathbb{R}^d$，若双侧极限

$$D_{\boldsymbol{v}}f(\boldsymbol{a})=\lim_{t\to 0}\frac{f(\boldsymbol{a}+t\boldsymbol{v})-f(\boldsymbol{a})}{t}$$

存在且有限，就称它为沿 $\boldsymbol{v}$ 的**方向导数**（directional derivative）。

回到地形的比喻：站在 $\boldsymbol{a}$ 上方，沿地图上的方向 $\boldsymbol{v}$ 前进，方向导数就是脚下的坡度。取 $\boldsymbol{v}=\boldsymbol{e}_j$ 便回到偏导数。定义用的是双侧极限；只令 $t\downarrow 0$ 得到的单侧方向导数是另一个概念，存在与否要分别判断。若基点在定义域的边界上，例如闭区域的边界点，只有指向区域内部的方向才允许取小的正步长，这时只能讨论单侧差商，并须先说明哪些方向可以使用。本章只在开集内部使用双侧定义。

本书允许 $\boldsymbol{v}$ 不是单位向量。这时导数按参数 t 计量：t 增加 1，水平位置移动 $\|\boldsymbol{v}\|_2$。若要表示每单位水平距离的变化率，应取 $\|\boldsymbol{v}\|_2=1$。比较同一条直线的两种参数化，就能看到方向向量的长度怎样改变方向导数的数值。

示例 17.6　沿对角方向的方向导数　仍取 $f(x,y)=x^2+xy+y^2$，从 $(1,2)$ 沿 $\boldsymbol{v}=(1,1)^{\top}$ 移动，展开得

$$f(1+t,2+t)=(1+t)^2+(1+t)(2+t)+(2+t)^2=7+9t+3t^2,$$

所以 $D_{\boldsymbol{v}}f(1,2)=9$。改用同向单位向量 $\boldsymbol{u}=(1,1)^{\top}/\sqrt{2}$，参数 t 增加 1 时只走过单位距离，变化率为 $D_{\boldsymbol{u}}f(1,2)=9/\sqrt{2}\approx 6.36$。

两个方向向量描述同一条直线，只是参数速度不同，所以比较变化率时要先统一归一化约定。还可以注意到 $9=4\cdot 1+5\cdot 1$：沿 $(1,1)^{\top}$ 的变化率恰好是两个偏导数按方向分量加权之和。到这里我们只记录了一条条切片上的变化率。它们能否组成一个对所有方向、乃至方向不断改变的扰动都有效的线性近似，是下一小节要回答的问题。

17.2.2　全微分与可微性判别

一元可微的含义是 $f(a+h)=f(a)+f'(a)h+o(h)$：在 a 附近，函数图像可以用一条切线代替，误差比 h 小得多。把图像放大来看，曲线越来越像一条直线。两个输入时，与切线对应的是切平面。把曲面 $z=f(x,y)$ 在一点附近不断放大，如果它越来越像一张平面，就说 f 在该点可微；这张平面给出函数增量的线性近似。

预测增量的规则应与扰动的叠加和数乘相容，所以用线性映射 $A:\mathbb{R}^d\to\mathbb{R}$ 来预测。例如 $A(\boldsymbol{h})=\boldsymbol{c}^{\top}\boldsymbol{h}$ 把每个坐标的扰动乘以固定系数再相加。此外，预测遗漏的误差必须比扰动长度小得多。

定义 17.7　多元标量函数的可微性与全微分　设 $U\subseteq\mathbb{R}^d$ 开，$f:U\to\mathbb{R}$，$\boldsymbol{a}\in U$。若存在一个线性映射 $A:\mathbb{R}^d\to\mathbb{R}$，使

$$f(\boldsymbol{a}+\boldsymbol{h})=f(\boldsymbol{a})+A(\boldsymbol{h})+o(\|\boldsymbol{h}\|_2)\qquad \boldsymbol{h}\to\boldsymbol{0},\tag{17.1}$$

则称 f 在 $\boldsymbol{a}$ 处**可微**（differentiable）。线性映射 A 称为该点的**全微分**（total differential），记为 $\mathrm{d}f_{\boldsymbol{a}}$。

余项条件是

$$\frac{|f(\boldsymbol{a}+\boldsymbol{h})-f(\boldsymbol{a})-A(\boldsymbol{h})|}{\|\boldsymbol{h}\|_2}\longrightarrow 0,$$

其中 $\boldsymbol{h}\to\boldsymbol{0}$ 按第 3.2.3.1节的联合极限理解。它要求同一个 A 适用于全部趋零扰动，而不是先固定一个方向、再按方向分别控制误差。$d=2$ 时，$z=f(\boldsymbol{a})+A(\boldsymbol{x}-\boldsymbol{a})$ 是三维空间中经过 $(\boldsymbol{a},f(\boldsymbol{a}))$ 的一张平面，即切平面。余项条件说的是：曲面与切平面的高度差比到 $\boldsymbol{a}$ 的水平距离小得多。

用数值可以看到这个“小得多”。

示例 17.8 切平面误差随步长缩小 仍看 $f(x,y)=x^2+xy+y^2$ 在 $(1,2)$ 处，用线性映射 $A(h,k)=4h+5k$ 预测增量（示例 17.10将证明它就是全微分），并观察误差相对步长怎样变化。沿 $(h,k)=(0.01,0.02)$ 走一步，切平面预测 $7+0.04+0.10=7.14$，实际值 $f(1.01,2.02)=7.1407$，误差为 0.0007，与步长 $\sqrt{0.01^2+0.02^2}\approx 0.0224$ 之比约为 0.031。把步长减半为 $(0.005,0.01)$，误差缩小到 0.000175，只有原来的四分之一；它与步长 ≈ 0.0112 之比约为 0.016，恰好减半。

误差与步长之比随步长减半而减半；步长继续缩小时，这个比值趋于零，这正是余项条件的要求。

可微性的要求与判别 以下固定开集 $U\subseteq\mathbb{R}^d$、标量函数 $f:U\to\mathbb{R}$ 与基点 $\boldsymbol{a}\in U$。先看可微必然带来什么，再给出一个便于核查的充分条件，最后用反例区分偏导数存在、全部双侧方向导数存在、可微和连续可微。

可微的必要条件 若同一个线性近似对全部扰动有效，把扰动限制在一条直线上，它就必须与这条直线上的一元导数相同；函数增量本身也必须趋于零。由这两点可以把全微分与偏导数及方向导数联系起来。

定理 17.9 可微性与偏导数、方向导数 若 $f:U\to\mathbb{R}$ 在 $\boldsymbol{a}$ 处可微，则 f 在该点连续，各偏导数存在，全微分唯一，并且

$$\mathrm{d}f_{\boldsymbol{a}}(\boldsymbol{h})=\sum_{j=1}^{d}\partial_j f(\boldsymbol{a})h_j$$

$$D_{\boldsymbol{v}}f(\boldsymbol{a})=\mathrm{d}f_{\boldsymbol{a}}(\boldsymbol{v})\quad(\boldsymbol{v}\in\mathbb{R}^d).$$

证明 记 $A=\mathrm{d}f_{\boldsymbol{a}}$。先证连续。把 $\boldsymbol{h}$ 按标准基写成 $\sum_j h_j\boldsymbol{e}_j$，线性性给出 $A(\boldsymbol{h})=\sum_j h_j A(\boldsymbol{e}_j)$。由有限和的 Cauchy–Schwarz 不等式，

$$|A(\boldsymbol{h})|\le\left(\sum_{j}|A(\boldsymbol{e}_j)|^2\right)^{1/2}\|\boldsymbol{h}\|_2,$$

这也就是第 3.3.4节所说的有限维线性映射的 Lipschitz 连续性。因此在式 (17.1)中，线性项与余项都随 $\boldsymbol{h}\to\boldsymbol{0}$ 而趋零，即 $f(\boldsymbol{a}+\boldsymbol{h})\to f(\boldsymbol{a})$，$f$ 连续。

再求系数。取 $\boldsymbol{h} = t\boldsymbol{e}_j$，式 (17.1)变成 $f(\boldsymbol{a}+t\boldsymbol{e}_j) - f(\boldsymbol{a}) = tA(\boldsymbol{e}_j) + o(|t|)$；两边除以 t 并令 $t \to 0$，可知偏导数存在且 $\partial_j f(\boldsymbol{a}) = A(\boldsymbol{e}_j)$。代回线性展开，得到 $A(\boldsymbol{h}) = \sum_j \partial_j f(\boldsymbol{a}) h_j$。任何满足式 (17.1)的线性映射在每个 $\boldsymbol{e}_j$ 上的值都由同一个偏导数确定，所以全微分唯一。最后对固定的 $\boldsymbol{v} \neq \boldsymbol{0}$ 取 $\boldsymbol{h} = t\boldsymbol{v}$：差商等于 $A(\boldsymbol{v})$ 加上余项除以 t，而余项是 $o(|t|\|\boldsymbol{v}\|_2)$，除以 t 后仍趋零，就得到方向导数公式；$\boldsymbol{v} = \boldsymbol{0}$ 时差商恒为零。 ■

定理说明，一旦可微，全微分只能是以各偏导数为系数的线性映射，所有方向导数也都由这 d 个偏导数线性地决定。因此验证可微时，候选线性映射已经确定，只需再估计余项。对本章的二次函数，这一步可以直接完成。

示例 17.10　二元二次函数的全微分　对二次函数 $f(x,y) = x^2 + xy + y^2$，在 $(1,2)$ 处两个偏导数为 4 与 5，候选线性映射为 $(h,k) \mapsto 4h + 5k$。

设扰动为 (h,k)，直接展开得

$$f(1+h, 2+k) = 7 + 4h + 5k + (h^2 + hk + k^2).$$

由 $|hk| \le (h^2+k^2)/2$，最后一项绝对值不超过 $3(h^2+k^2)/2$；除以 $\sqrt{h^2+k^2}$ 后不超过 $\tfrac{3}{2}\sqrt{h^2+k^2}$，随扰动趋于零。所以全微分确为 $\mathrm{d}f_{(1,2)}(h,k) = 4h + 5k$，切平面为 $z = 7 + 4(x-1) + 5(y-2)$。

这个全微分同时给出了示例 17.4中的两个偏导数，以及示例 17.6中沿 $(1,1)^{\mathsf{T}}$ 的变化率 $4 + 5 = 9$。图 17.1画出了这个切平面，以及对所有方向同时成立的余项界。

偏导数连续给出的充分条件　按定义验证可微需要估计余项，通常不方便。另一种判别只检查偏导数：如果各坐标的变化率在基点附近连续变化，就可以沿坐标逐段走，用它们共同控制全部坐标增量。与定理 17.9不同，这是一个充分条件，直接保证全微分存在。

定理 17.11　偏导数连续与可微性　设 $f : U \to \mathbb{R}$，U 开，$\boldsymbol{a} \in U$。若各一阶偏导数在 $\boldsymbol{a}$ 的某个邻域内存在，并在 $\boldsymbol{a}$ 处连续，则 f 在 $\boldsymbol{a}$ 处可微。

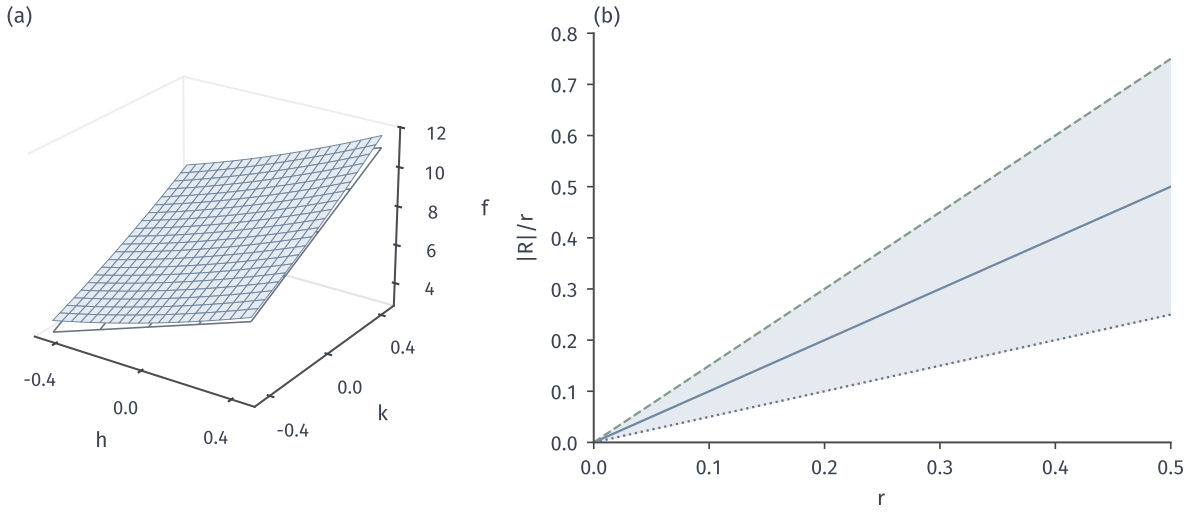


图 17.1 (a) 二次函数在 $(1,2)$ 附近，灰网格是切平面 $P = 7 + 4h + 5k$，蓝面是 $f(1+h, 2+k)$。(b) 令 $r = \sqrt{h^2 + k^2}$，余项 $R = h^2 + hk + k^2$ 满足 $r/2 \le R/r \le 3r/2$；阴影给出所有方向的完整范围，三条线是其中的代表值。共同上界随 $r \to 0$ 趋零，才保证任意方向都适用同一个线性近似。

证明 先看 $d = 2$。从 (a_1, a_2) 走到 $(a_1 + h_1, a_2 + h_2)$，可以先竖直走、再水平走：

$$\begin{aligned} &f(a_1 + h_1, a_2 + h_2) - f(a_1, a_2) \\ &= \big[f(a_1 + h_1, a_2 + h_2) - f(a_1, a_2 + h_2)\big] \\ &\quad + \big[f(a_1, a_2 + h_2) - f(a_1, a_2)\big]. \end{aligned}$$

第一个方括号只改变第一个坐标，对一元函数 $s \mapsto f(s, a_2 + h_2)$ 用中值定理，得到它等于 $\partial_1 f(\boldsymbol{\xi}_1) h_1$，其中 $\boldsymbol{\xi}_1$ 在这段水平线段上；第二个方括号同理等于 $\partial_2 f(\boldsymbol{\xi}_2) h_2$，$\boldsymbol{\xi}_2$ 在竖直线段上。这里用到 $\boldsymbol{h}$ 足够小时两段都在偏导数存在的邻域内。

一般的 d 同样把 $\boldsymbol{a}$ 到 $\boldsymbol{a} + \boldsymbol{h}$ 的增量拆成 d 段，每段只改一个坐标，一元中值定理将第 j 段增量写成 $\partial_j f(\boldsymbol{\xi}_j) h_j$，$\boldsymbol{\xi}_j$ 是第 j 段上的中间点。减去候选线性项后，误差为 $\sum_j \big(\partial_j f(\boldsymbol{\xi}_j) - \partial_j f(\boldsymbol{a})\big) h_j$，因此

$$\begin{aligned} &\left| f(\boldsymbol{a} + \boldsymbol{h}) - f(\boldsymbol{a}) - \sum_{j=1}^{d} \partial_j f(\boldsymbol{a}) h_j \right| \\ &\qquad \le \max_j \left| \partial_j f(\boldsymbol{\xi}_j) - \partial_j f(\boldsymbol{a}) \right| \sum_{j=1}^{d} |h_j| = o(\|\boldsymbol{h}\|_2). \end{aligned}$$

最后一步有两个依据：当 $\boldsymbol{h} \to \boldsymbol{0}$ 时，所有中间点到 $\boldsymbol{a}$ 的距离都不超过 $\|\boldsymbol{h}\|_2$，偏导数在 $\boldsymbol{a}$ 处连续，使最大值一项趋于零；另一方面

$\sum_j |h_j| \le \sqrt{d}\|\boldsymbol{h}\|_2$。这样，各坐标方向上的变化就拼成了同一个有效的全微分。 ■

偏导数连续只是充分条件：可微只要求函数增量有统一的一阶近似，不要求这些系数随基点连续变化。实际计算中，若各偏导数在所论开集上由连续的表达式给出，就可以直接断定可微。多项式、分母非零的有理函数，以及它们与指数、正弦等连续函数的复合，都属于这种情形。

连续可微函数　若要求全微分的系数在一个范围内随基点连续变化，就得到连续可微的概念。实值函数的各一阶偏导数在开集 U 上存在且连续时，称它在 U 上连续可微，记为 $C^1(U)$；$C^k(U)$ 表示直至 k 阶的各偏导数都存在且连续。定理 17.11保证 C^1 函数处处可微。逆向并不成立，一元函数就足以说明这一点。

示例 17.12　处处可微而导数无界　在实轴上令 $r(0)=0$，$x\neq 0$ 时令 $r(x)=x^2\sin(1/x^2)$。由于 $|r(h)/h| = |h\sin(1/h^2)| \le |h| \to 0$，有 $r'(0)=0$；非零点按运算法则求导，得到

$$r'(x) = 2x\sin(1/x^2) - \frac{2}{x}\cos(1/x^2).$$

取 $x_n = (2\pi n)^{-1/2}$，则 $1/x_n^2 = 2\pi n$，sin 项为 0、cos 项为 1，于是 $r'(x_n) = -2/x_n \to -\infty$。所以 r 处处可微，r' 却在 0 附近无界，在 0 处不连续。直观上，r 的振幅被 x^2 压到零，图像在原点与横轴相切；但振荡越来越快，切线斜率剧烈摆动。在多元情形令 $f(\boldsymbol{x}) = r(x_1)$，就得到处处可微而非连续可微的标量函数。

这个例子还说明可微不保证局部 Lipschitz 连续（定义 3.22）。若 r 在原点的某个邻域内以 L 为 Lipschitz 常数，该邻域内每个差商的绝对值都不超过 L，各点导数也就满足 $|r'|\le L$，与 $r'(x_n)\to-\infty$ 矛盾。

必要条件不能反推可微　可微蕴含连续、偏导数存在和全部双侧方向导数存在。一元函数在一点的导数存在就等价于可微，因为实轴上只有一条直线可走。多元函数还须协调无穷多个输入方向以及弯曲的趋近路径，所以这些必要条件单独或合起来都不能保证可微。下面依次检查它们的逆向。

偏导数存在不保证可微　坐标偏导数只约束两条坐标切片，并未控制其余方向或路径。

示例 17.13　偏导数存在但不可微　定义 $f:\mathbb{R}^2\to\mathbb{R}$ 为

$$f(x,y)=\begin{cases}\dfrac{xy}{\sqrt{x^2+y^2}}, & (x,y)\neq(0,0),\\[2mm] 0, & (x,y)=(0,0).\end{cases}$$

沿两条坐标轴，函数恒为 0，所以 $\partial f/\partial x(0,0)=\partial f/\partial y(0,0)=0$。若 f 在原点可微，由定理 17.9，候选线性部分只能是零映射。可是沿 $\boldsymbol{h}=(t,t)$，

$$\frac{|f(t,t)-f(0,0)|}{\|(t,t)\|_2}=\frac{|t|/\sqrt{2}}{\sqrt{2}|t|}=\frac{1}{2},$$

余项与 $\|\boldsymbol{h}\|_2$ 之比不趋于零，故 f 在原点不可微。

用极坐标可以看清曲面的形状：$f=r\cos\theta\sin\theta=\frac{r}{2}\sin 2\theta$。沿每条从原点出发的射线，函数随 r 线性增长，斜率 $\frac{1}{2}\sin 2\theta$ 随方向变化。曲面由这些射线组成，像一个起伏的锥面；把它放大任意倍数后形状不变，永远不会变得像一张平面。

沿每个方向 $\boldsymbol{v}=(a,b)$，只令 $t\downarrow 0$ 的正向方向导数都存在，等于 $ab/\sqrt{a^2+b^2}$（零方向取 0），但它不是关于 $\boldsymbol{v}$ 的线性函数。$t<0$ 时差商变号，因此 $ab\neq 0$ 时双侧方向导数不存在。最后，由 $|xy|/\sqrt{x^2+y^2}\le\sqrt{x^2+y^2}/2$，$f$ 在原点连续。

偏导数只看坐标轴，遗漏了其他接近方向；可微则要求曲面放大后接近平面，本例的锥面做不到。本例还说明，即使偏导数存在、全部正向方向导数存在、函数又连续，也推不出可微。这里的正向方向导数是单侧极限，与本节采用的双侧定义不同，使用时要分清。

全部方向导数存在不保证可微　把坐标切片换成所有固定直线，仍有两件事需要检查：这些变化率能否组成一个线性映射，以及是否有统一的余项控制。先看缺少线性性的情形。

示例 17.14　方向导数不构成线性映射　在非原点处令 $p(x,y)=x^3/(x^2+y^2)$，并令 $p(0,0)=0$。沿 $\boldsymbol{v}=(a,b)\neq\boldsymbol{0}$，差商为 $p(ta,tb)/t=a^3/(a^2+b^2)$，不依赖 t，所以双侧方向导数存在且 $D_{\boldsymbol{v}}p(0,0)=a^3/(a^2+b^2)$。取坐标方向得到两个偏导数 1 与 0。若 p 可微，由定理 17.9，沿 $(1,1)^{\mathsf{T}}$ 的方向导数应为 $1\cdot 1+0\cdot 1=1$，实际却是 $1/(1+1)=1/2$。这些方向变化率无法拼成一个线性映射，所以 p 在原点不可微。

示例 17.13只有单侧方向导数；这里的双侧方向导数全部存在，失败只来自线性性。即使方向导数全部存在并组成一个线性映射，还要检查余项能否统一控制。

示例 17.15　方向导数全为零仍不可微　在非原点处令 $q(x,y) = x^3y/(x^4+y^2)$，并令 $q(0,0)=0$。由 $2|x^2y| \le x^4+y^2$，有 $|q(x,y)| \le |x|/2$，故 q 在原点连续。对固定方向 $(a,b)^{\top}$，若 $b \neq 0$，

$$\frac{q(ta,tb)}{t} = \frac{ta^3b}{t^2a^4+b^2} \longrightarrow 0;$$

若 $b=0$，差商恒为零。因此所有双侧方向导数都为零，它们组成零线性映射。可是沿 $\boldsymbol{h}=(t,t^2)^{\top}$，$q(t,t^2)=t^5/(2t^4)=t/2$，从而

$$\frac{|q(t,t^2)|}{\|(t,t^2)\|_2} = \frac{1}{2\sqrt{1+t^2}} \longrightarrow \frac{1}{2}.$$

候选零映射不满足全微分的余项条件，q 在原点不可微。

这与示例 3.17中 g 的情形相同：函数沿抛物线有一道坡，每条直线进入原点时都避开了它。方向导数先固定方向再取极限；全微分则要求方向随扰动改变时，误差仍受同一个控制。

连续与偏导数存在互不蕴含　连续性也推不出微分条件。例如 $f(x,y)=|x|$ 在整个平面上 Lipschitz 连续，图像沿 y 轴有一道折痕。原点关于 x 的双侧偏导数不存在，因此 f 在那里不可微。偏导数存在同样推不出连续：示例 3.16中原点置零的 $xy/(x^2+y^2)$ 沿坐标轴恒为零，两个偏导数存在，但它在原点不连续。所以连续与偏导数存在互不蕴含，可微则同时保证二者。

条件之间的蕴含关系　把必要条件、充分判别与上面的反例放在一起，得到下面的蕴含链：

$$f\text{在}\boldsymbol{a}\text{的某邻域内连续可微} \implies f\text{在}\boldsymbol{a}\text{处可微},$$
$$f\text{在}\boldsymbol{a}\text{处可微} \implies \text{全部双侧方向导数存在} \implies \text{全部偏导数存在}.$$

第一条由定理 17.11得到，第二条由定理 17.9得到，最后一条只须在全部方向中取坐标方向 $\boldsymbol{e}_j$。同一定理还说明，可微蕴含连续，并且方向导数关于方向是线性映射 $\boldsymbol{v} \mapsto \mathrm{d}f_{\boldsymbol{a}}(\boldsymbol{v})$。第一行的前提涉及 $\boldsymbol{a}$ 的整个邻域，其余条件只涉及基点 $\boldsymbol{a}$ 本身；链中的方向导数都按双侧极限理解。

各箭头都不能反向：示例 17.12说明处处可微仍可能不连续可微；示例 17.14与示例 17.15说明全部双侧方向导数存在仍可能不可微，后者连函

数连续、方向导数组成线性映射这两点也都满足；示例 17.13说明偏导数存在不推出全部双侧方向导数存在。不满足偏导数连续这一充分条件时，应回到全微分的定义检查余项。

17.2.3 微分的运算法则

直接按定义求全微分很繁琐。与一元情形一样，可以从简单函数的微分出发，用运算法则组合出复杂函数的微分。本小节的 f, g 都在同一开集内定义，并在基点 $\boldsymbol{a}$ 处可微，c 为固定实数。各法则的证明方法相同：代入各自的一阶展开，整理出关于 $\boldsymbol{h}$ 的线性项，再确认剩下的部分仍是 $o(\|\boldsymbol{h}\|_2)$。这样既证明新函数可微，也读出了它的全微分。

和、差与数乘的微分 把两个一阶展开相加，

$$(f+g)(\boldsymbol{a}+\boldsymbol{h}) = (f+g)(\boldsymbol{a}) + \big(\mathrm{d}f_{\boldsymbol{a}} + \mathrm{d}g_{\boldsymbol{a}}\big)(\boldsymbol{h}) + o(\|\boldsymbol{h}\|_2),$$

两个线性映射之和仍是线性映射，两个 $o(\|\boldsymbol{h}\|_2)$ 余项之和仍是 $o(\|\boldsymbol{h}\|_2)$，因此 $\mathrm{d}(f+g) = \mathrm{d}f + \mathrm{d}g$。把加号换成减号，同样的论证给出 $\mathrm{d}(f-g) = \mathrm{d}f - \mathrm{d}g$。固定系数 c 只会缩放线性项与余项，故 $\mathrm{d}(cf) = c\,\mathrm{d}f$，包括 $c=0$ 的常函数情形。

积的微分 记 R_f, R_g 为两个一阶展开的余项，都是 $o(\|\boldsymbol{h}\|_2)$。相乘得

$$\begin{aligned} f(\boldsymbol{a}+\boldsymbol{h})g(\boldsymbol{a}+\boldsymbol{h}) &= \big(f(\boldsymbol{a}) + \mathrm{d}f(\boldsymbol{h}) + R_f\big)\big(g(\boldsymbol{a}) + \mathrm{d}g(\boldsymbol{h}) + R_g\big) \\ &= f(\boldsymbol{a})g(\boldsymbol{a}) + g(\boldsymbol{a})\,\mathrm{d}f(\boldsymbol{h}) + f(\boldsymbol{a})\,\mathrm{d}g(\boldsymbol{h}) + (\text{其余各项}). \end{aligned}$$

其余各项要么含有余项 R_f, R_g 乘以有界量，要么是两个线性增量的乘积 $\mathrm{d}f(\boldsymbol{h})\,\mathrm{d}g(\boldsymbol{h}) = O(\|\boldsymbol{h}\|_2^2)$，都是 $o(\|\boldsymbol{h}\|_2)$。因此乘积可微，且

$$\mathrm{d}(fg) = g(\boldsymbol{a})\,\mathrm{d}f + f(\boldsymbol{a})\,\mathrm{d}g.$$

这与一元的 $(fg)' = f'g + fg'$ 形式相同：两个因子各自变化，一阶上贡献可以相加，两个变化同时发生的部分是高阶小量。

商的微分 设 $g(\boldsymbol{a}) \neq 0$。可微蕴含连续，所以 g 在 $\boldsymbol{a}$ 附近远离零，$1/g$ 在 $\boldsymbol{a}$ 附近有定义。记 $\delta = g(\boldsymbol{a}+\boldsymbol{h}) - g(\boldsymbol{a}) = \mathrm{d}g(\boldsymbol{h}) + o(\|\boldsymbol{h}\|_2)$，它是 $O(\|\boldsymbol{h}\|_2)$。一元函数 $1/y$ 在 $g(\boldsymbol{a})$ 处的展开给出

$$\frac{1}{g(\boldsymbol{a})+\delta} = \frac{1}{g(\boldsymbol{a})} - \frac{\delta}{g(\boldsymbol{a})^2} + O(\delta^2).$$

代入 δ 的展开，并注意 $O(\delta^2)=O(\|\boldsymbol{h}\|_2^2)$，得到 $\mathrm{d}(1/g)=-\mathrm{d}g/g(\boldsymbol{a})^2$。再把 f/g 看成 $f\cdot(1/g)$，用积的微分得到

$$\mathrm{d}(f/g)=\frac{g(\boldsymbol{a})\,\mathrm{d}f-f(\boldsymbol{a})\,\mathrm{d}g}{g(\boldsymbol{a})^2}.$$

这里分母非零既是定义商函数的条件，也是估计余项的条件。

标量复合函数的微分　若一元函数 ψ 在 $f(\boldsymbol{a})$ 处可微，且复合在 $\boldsymbol{a}$ 的邻域内有定义，则 $\psi\circ f$ 在 $\boldsymbol{a}$ 处可微，并且

$$\mathrm{d}(\psi\circ f)=\psi'(f(\boldsymbol{a}))\,\mathrm{d}f.$$

推导时把内层增量 $\delta=f(\boldsymbol{a}+\boldsymbol{h})-f(\boldsymbol{a})$ 代入外层的一元展开 $\psi(f(\boldsymbol{a})+\delta)=\psi(f(\boldsymbol{a}))+\psi'(f(\boldsymbol{a}))\delta+o(|\delta|)$，再把 $\delta=\mathrm{d}f(\boldsymbol{h})+o(\|\boldsymbol{h}\|_2)$ 代入。因为 $\delta=O(\|\boldsymbol{h}\|_2)$，外层余项 $o(|\delta|)$ 仍是 $o(\|\boldsymbol{h}\|_2)$。例如 $-(x^2+y^2)$ 在 (x,y) 处的全微分为 $(h,k)\mapsto -2xh-2yk$，所以 $e^{-(x^2+y^2)}$ 的全微分是 $(h,k)\mapsto e^{-(x^2+y^2)}(-2xh-2yk)$：外层只把内层的全微分乘上一个正数。

沿参数曲线的变化率　外层也可以是多元函数、内层是一元的参数曲线。设 $\boldsymbol{x}:I\to U$ 定义在开区间 I 上，各坐标在 t_0 处可微，记速度向量 $\boldsymbol{x}'(t_0)=(x_1'(t_0),\dots,x_d'(t_0))^{\top}$；又设 f 在 $\boldsymbol{a}=\boldsymbol{x}(t_0)$ 处可微。则 $t\mapsto f(\boldsymbol{x}(t))$ 在 t_0 处可微，且

$$\frac{\mathrm{d}}{\mathrm{d}t}f(\boldsymbol{x}(t))\Big|_{t=t_0}=\mathrm{d}f_{\boldsymbol{a}}(\boldsymbol{x}'(t_0))=\sum_{j=1}^{d}\partial_j f(\boldsymbol{a})\,x_j'(t_0).\tag{17.2}$$

推导与上一段相同。记内层增量 $\boldsymbol{k}=\boldsymbol{x}(t_0+s)-\boldsymbol{x}(t_0)$，各坐标的一元展开给出 $\boldsymbol{k}=s\boldsymbol{x}'(t_0)+o(|s|)$，因而 $\|\boldsymbol{k}\|_2=O(|s|)$。代入 f 的一阶展开，

$$f(\boldsymbol{x}(t_0+s))-f(\boldsymbol{a})=\mathrm{d}f_{\boldsymbol{a}}(\boldsymbol{k})+o(\|\boldsymbol{k}\|_2)=s\,\mathrm{d}f_{\boldsymbol{a}}(\boldsymbol{x}'(t_0))+o(|s|),$$

第二步用了全微分的线性，以及线性映射把长度为 $o(|s|)$ 的向量仍变成 $o(|s|)$ 的数。除以 s 并令 $s\to 0$ 即得。内层的变化先在输入空间中产生速度向量 $\boldsymbol{x}'(t_0)$，外层的全微分再作用于这个方向。取直线 $\boldsymbol{x}(t)=\boldsymbol{a}+t\boldsymbol{v}$，便回到方向导数公式 $D_{\boldsymbol{v}}f(\boldsymbol{a})=\mathrm{d}f_{\boldsymbol{a}}(\boldsymbol{v})$。下一小节用式 (17.2)说明梯度与等值曲线的切向正交；一般向量值映射的复合在第 17.3.2节处理。

二次型的微分　二次型是向量自变量的标量函数，平方误差、能量函数等都含有这种结构。考虑 $q(\boldsymbol{x})=\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x}=\sum_{i,j}A_{i,j}x_ix_j$，其中 $\boldsymbol{A}\in\mathbb{R}^{d\times d}$ 固定。

它是有限个乘积的和，可以直接用乘积法则：把两个 $\boldsymbol{x}$ 看成两个因子，每次只让一个变化，

$$\begin{aligned} \mathrm{d}q_{\boldsymbol{x}}(\boldsymbol{h}) &= \boldsymbol{h}^{\top}\boldsymbol{A}\boldsymbol{x} + \boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{h} \\ &= \boldsymbol{x}^{\top}(\boldsymbol{A}^{\top} + \boldsymbol{A})\boldsymbol{h}. \end{aligned}$$

第二步用到 $\boldsymbol{h}^{\top}\boldsymbol{A}\boldsymbol{x}$ 是一个实数，等于自己的转置 $\boldsymbol{x}^{\top}\boldsymbol{A}^{\top}\boldsymbol{h}$。所以全微分的系数，即各偏导数排成的列向量，为

$$\big(\partial_1 q(\boldsymbol{x}), \dots, \partial_d q(\boldsymbol{x})\big)^{\top} = (\boldsymbol{A} + \boldsymbol{A}^{\top})\boldsymbol{x}. \tag{17.3}$$

当 $\boldsymbol{A}$ 对称时，式 (17.3)化为 $2\boldsymbol{A}\boldsymbol{x}$，与一元的 $(ax^2)' = 2ax$ 对应。$\boldsymbol{A}$ 不对称时不能写成 $2\boldsymbol{A}\boldsymbol{x}$，否则就默认了对称性。例如

$$\boldsymbol{A} = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$$

时 $q = x_1 x_2$，直接求偏导得 $(x_2, x_1)^{\top}$，与 $(\boldsymbol{A}+\boldsymbol{A}^{\top})\boldsymbol{x}$ 一致；而 $2\boldsymbol{A}\boldsymbol{x} = (2x_2, 0)^{\top}$ 是错的。

二次型的精确增量　乘积法则只给出一阶项。对二次型还可以直接写出完整增量，把一阶项与实际误差放在同一个式子里。设 $\boldsymbol{S}$ 对称，展开得

$$q(\boldsymbol{x}+\boldsymbol{h}) - q(\boldsymbol{x}) = \boldsymbol{h}^{\top}\boldsymbol{S}\boldsymbol{x} + \boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{h} + \boldsymbol{h}^{\top}\boldsymbol{S}\boldsymbol{h} = 2\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{h} + \boldsymbol{h}^{\top}\boldsymbol{S}\boldsymbol{h},$$

其中用到 $\boldsymbol{h}^{\top}\boldsymbol{S}\boldsymbol{x} = (\boldsymbol{h}^{\top}\boldsymbol{S}\boldsymbol{x})^{\top} = \boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{h}$。由 Cauchy–Schwarz 不等式与谱范数的定义（第 3.3.4节），

$$|\boldsymbol{h}^{\top}\boldsymbol{S}\boldsymbol{h}| \le \|\boldsymbol{h}\|_2 \|\boldsymbol{S}\boldsymbol{h}\|_2 \le \|\boldsymbol{S}\|_2 \|\boldsymbol{h}\|_2^2.$$

所以余项不只是 $o(\|\boldsymbol{h}\|_2)$，而是被一个明确的二次量控制；这也独立地证明了 q 可微，且 $\mathrm{d}q_{\boldsymbol{x}}(\boldsymbol{h}) = 2\boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{h}$。例如 $x^2 + xy + y^2 = \boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}$，其中

$$\boldsymbol{S} = \begin{bmatrix} 1 & 1/2 \\ 1/2 & 1 \end{bmatrix}$$

的特征值为 $3/2$ 与 $1/2$。对称矩阵的谱范数是特征值绝对值的最大者（第 4章），故 $\|\boldsymbol{S}\|_2 = 3/2$，这正是示例 17.10中余项上界 $\frac{3}{2}(h^2 + k^2)$ 的常数。二次项 $\boldsymbol{h}^{\top}\boldsymbol{S}\boldsymbol{h}$ 在第 17.4节成为 Hessian 二次型，梯度和余项估计也将复用这个例子。

17.2.4　梯度与内积

可微时，全微分 $\mathrm{d}f_{\boldsymbol{a}}$ 是 $\mathbb{R}^d$ 上的线性泛函，即对偶空间中的元素（第 2.4节）：它读取一个输入扰动，给出函数值的一阶变化。泛函本身不是输入空间中的向量，不能画成地图上的箭头。第 3.6.1节的 Riesz 表示定理说明，选定内积后，每个线性泛函都等于与唯一一个向量的内积。把这个向量作为全微分的表示，就得到梯度。

定义 17.16　梯度　设 $\mathbb{R}^d$ 上取定内积 $\langle\cdot,\cdot\rangle$，$f:U\to\mathbb{R}$ 在 $\boldsymbol{a}$ 处可微。满足

$$\mathrm{d}f_{\boldsymbol{a}}(\boldsymbol{h})=\langle\nabla f(\boldsymbol{a}),\boldsymbol{h}\rangle\qquad(\boldsymbol{h}\in\mathbb{R}^d)$$

的唯一向量 $\nabla f(\boldsymbol{a})\in\mathbb{R}^d$ 称为 f 在 $\boldsymbol{a}$ 处的**梯度**（gradient）。未加说明时取标准欧氏内积 $\langle\boldsymbol{x},\boldsymbol{y}\rangle=\boldsymbol{x}^{\top}\boldsymbol{y}$。

在标准欧氏内积下，比较定理 17.9中的 $\mathrm{d}f_{\boldsymbol{a}}(\boldsymbol{h})=\sum_j\partial_j f(\boldsymbol{a})h_j$ 与 $\nabla f(\boldsymbol{a})^{\top}\boldsymbol{h}$，逐个取 $\boldsymbol{h}=\boldsymbol{e}_j$，得到

$$\nabla f(\boldsymbol{a})=\big(\partial_1 f(\boldsymbol{a}),\dots,\partial_d f(\boldsymbol{a})\big)^{\top}.\tag{17.4}$$

于是可微函数满足 $f(\boldsymbol{a}+\boldsymbol{h})=f(\boldsymbol{a})+\nabla f(\boldsymbol{a})^{\top}\boldsymbol{h}+o(\|\boldsymbol{h}\|_2)$，方向导数为 $D_{\boldsymbol{v}}f(\boldsymbol{a})=\nabla f(\boldsymbol{a})^{\top}\boldsymbol{v}$。例如 $f(x,y)=x^2+xy+y^2$ 的梯度为 $\nabla f(x,y)=(2x+y,x+2y)^{\top}$，$\nabla f(1,2)=(4,5)^{\top}$；由式 (17.3)，一般二次型有 $\nabla_{\boldsymbol{x}}(\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x})=(\boldsymbol{A}+\boldsymbol{A}^{\top})\boldsymbol{x}$。梯度与输入属于同一个空间：$(4,5)^{\top}$ 可以画成地图平面上从 $(1,2)$ 出发的一支箭头，而不是曲面上的向量。

若 f 在开集 U 上处处可微，把每一点的梯度放在该点，就得到 U 上的向量场 $\nabla f:U\to\mathbb{R}^d$，称为 f 的梯度场。例如第 17.1.1节的标量场 x^2+y^2 的梯度场是 $(2x,2y)^{\top}$，箭头从原点向外，离原点越远越长，与那里观察到的“等值圆越来越密”相符。哪些向量场是某个标量场的梯度场，留到第 22.4节研究。

表示向量随泛函线性变化，所以上一小节的法则直接改写为梯度的法则：$\nabla(f\pm g)=\nabla f\pm\nabla g$，$\nabla(cf)=c\nabla f$，$\nabla(fg)=g(\boldsymbol{a})\nabla f+f(\boldsymbol{a})\nabla g$，$\nabla(\psi\circ f)=\psi'(f(\boldsymbol{a}))\nabla f$。例如 $\nabla e^{-(x^2+y^2)}=e^{-(x^2+y^2)}(-2x,-2y)^{\top}$，与 $-(x^2+y^2)$ 的梯度同向，都指向原点。

偏导数向量与梯度　式 (17.4)的右侧在偏导数全部存在时就能写出，本书在这种情形下也用记号 $\nabla f(\boldsymbol{a})$ 表示这一列偏导数。但第 17.2.2节的反例说明，这时它只是坐标变化率排成的向量：示例 17.14中这一列是 $(1,0)^{\top}$，却给不出沿 $(1,1)^{\top}$ 的方向导数。只有确认可微以后，它才代表对所有方向同

时有效的一阶近似，才可以用内积计算任意方向导数，并解释为最快上升的方向。

梯度的列向量排列也来自所选内积和坐标：全微分本身是一个线性作用，标准欧氏内积把它的系数原样排成列向量。换用其他内积时，同一个全微分由另一个向量表示。

改变内积时的梯度 设 $\mathbb{R}^d$ 上的内积在标准坐标下写成 $\langle \boldsymbol{x}, \boldsymbol{y} \rangle_{\boldsymbol{G}} = \boldsymbol{x}^{\top} \boldsymbol{G} \boldsymbol{y}$，其中 $\boldsymbol{G}$ 对称正定。第 3.4.2.5节说明，任何内积在坐标下都是这种形式，$\boldsymbol{G}$ 就是基的 Gram 矩阵。记全微分的系数向量为 $\boldsymbol{c} = \big(\partial_j f(\boldsymbol{a})\big)_{j=1}^{d}$。要求 $\mathrm{d}f_{\boldsymbol{a}}(\boldsymbol{h}) = \boldsymbol{c}^{\top}\boldsymbol{h} = \boldsymbol{g}^{\top}\boldsymbol{G}\boldsymbol{h}$ 对所有 $\boldsymbol{h}$ 成立，等价于 $\boldsymbol{G}\boldsymbol{g} = \boldsymbol{c}$，所以

$$\nabla_{\boldsymbol{G}} f(\boldsymbol{a}) = \boldsymbol{G}^{-1} \big(\partial_j f(\boldsymbol{a})\big)_{j=1}^{d}. \tag{17.5}$$

系数向量 $\boldsymbol{c}$ 由函数本身决定；改变的只是用哪个向量来表示同一个全微分。

> **示例 17.17 加权内积下的梯度** 仍取 $f(x,y) = x^2 + xy + y^2$ 与基点 $(1,2)$，系数向量为 $(4,5)^{\top}$。改用 $\boldsymbol{G} = \operatorname{diag}(4,1)$ 给出的加权内积 $\langle \boldsymbol{x}, \boldsymbol{y} \rangle_{\boldsymbol{G}} = 4x_1y_1 + x_2y_2$，由式 (17.5)，
>
> $$\nabla_{\boldsymbol{G}} f(1,2) = \operatorname{diag}(1/4, 1)\,(4,5)^{\top} = (1,5)^{\top}.$$
>
> 核对：$\langle (1,5)^{\top}, (h,k)^{\top} \rangle_{\boldsymbol{G}} = 4h + 5k$，正是同一个全微分。欧氏梯度 $(4,5)^{\top}$ 与加权梯度 $(1,5)^{\top}$ 方向不同：加权长度把第一坐标的位移计为原来的两倍，沿它走同样的加权距离只需更小的坐标位移。

这与第 3.6.1节的结论一致：读取本身不变，表示向量随内积改变。

最陡上升方向 设 f 在 $\boldsymbol{a}$ 处可微，$\boldsymbol{u}$ 满足 $\|\boldsymbol{u}\| = 1$，这里的长度由所选内积诱导。由 Cauchy–Schwarz 不等式（定理 3.42），

$$D_{\boldsymbol{u}} f(\boldsymbol{a}) = \langle \nabla f(\boldsymbol{a}), \boldsymbol{u} \rangle \le \|\nabla f(\boldsymbol{a})\|.$$

梯度非零时，取 $\boldsymbol{u} = \nabla f(\boldsymbol{a}) / \|\nabla f(\boldsymbol{a})\|$ 即达到等号。所以在所选内积的单位长度约束下，梯度方向是局部上升最快的方向，最大坡度等于梯度的长度；反方向 $-\nabla f(\boldsymbol{a})$ 则下降最快。示例 17.17中，欧氏单位长度下最快方向沿 $(4,5)^{\top}$，加权单位长度下则沿 $(1,5)^{\top}$。“最快”总是相对某种长度而言的。

梯度与等值曲线　若 $\boldsymbol{u}$ 与梯度正交, 方向导数为零, 函数值一阶上不变。设 $\boldsymbol{x}: I \to U$ 是一条落在等值集 $\{\boldsymbol{y}: f(\boldsymbol{y}) = f(\boldsymbol{a})\}$ 中的可微曲线，$\boldsymbol{x}(t_0) = \boldsymbol{a}$。$f(\boldsymbol{x}(t))$ 恒为常数，由式 (17.2),

$$0 = \frac{\mathrm{d}}{\mathrm{d}t} f(\boldsymbol{x}(t))\Big|_{t=t_0} = \langle \nabla f(\boldsymbol{a}), \boldsymbol{x}'(t_0) \rangle,$$

所以梯度与这条曲线的切向量正交。这里假定了等值集中确有经过 $\boldsymbol{a}$ 的可微曲线；整个等值集在 $\boldsymbol{a}$ 附近是否为光滑曲线或曲面，还需要第 19章的隐函数定理及梯度非零这一非退化条件。梯度为零只说明一阶项消失，函数在该点附近怎样变化，要由第 17.4节的高阶微分继续判断。

图 17.2用同一个二次函数比较梯度方向、等值曲线切向及另一个单位方向。

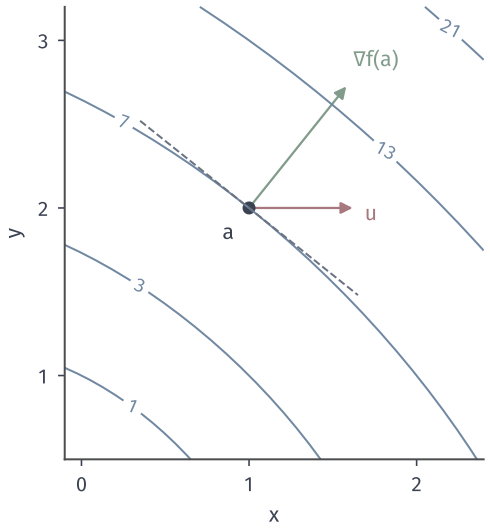


图 17.2　$f = x^2 + xy + y^2$ 的等值曲线，标注为函数值；基点 $a = (1, 2)$ 处 $\nabla f = (4, 5)^{\mathsf{T}}$，图中绿箭头按 0.15 倍绘制。灰虚线沿 $(5, -4)^{\mathsf{T}}$，与梯度垂直，因而与经过 a 的等值曲线相切；红箭头为 $u = (1, 0)^{\mathsf{T}}$。比较最快上升方向时须先归一化，不能直接比较图中箭头长度。

17.2.5　中值估计与局部 Lipschitz 性

微分描述一点附近的变化。要估计两点之间的有限变化，可以沿连接两点的线段把函数限制为一元函数，再使用一元中值定理。前提是整条线段都在定义域内。记 $[\boldsymbol{x}, \boldsymbol{y}] = \{\boldsymbol{x} + t(\boldsymbol{y} - \boldsymbol{x}) : 0 \le t \le 1\}$ 为连接两点的线段。

定理 17.18 多元标量函数的中值公式 设 f 在包含 $[\boldsymbol{x},\boldsymbol{y}]$ 的开集上可微，$\boldsymbol{x}\neq\boldsymbol{y}$。则存在 $\theta\in(0,1)$ 使

$$f(\boldsymbol{y})-f(\boldsymbol{x})=\nabla f(\boldsymbol{x}+\theta(\boldsymbol{y}-\boldsymbol{x}))^{\top}(\boldsymbol{y}-\boldsymbol{x}).$$

证明 令 $\phi(t)=f(\boldsymbol{x}+t(\boldsymbol{y}-\boldsymbol{x}))$，$t\in[0,1]$，它是 f 在线段上的一元切片。$\phi'(t)$ 就是 f 在点 $\boldsymbol{x}+t(\boldsymbol{y}-\boldsymbol{x})$ 处沿 $\boldsymbol{y}-\boldsymbol{x}$ 的方向导数，所以 $\phi'(t)=\nabla f(\boldsymbol{x}+t(\boldsymbol{y}-\boldsymbol{x}))^{\top}(\boldsymbol{y}-\boldsymbol{x})$。对 ϕ 在 $[0,1]$ 上使用一元中值定理，$\phi(1)-\phi(0)=\phi'(\theta)$，这就是所述等式。 ■

等式说明，两点之间的平均变化率等于线段上某一点沿该方向的瞬时变化率。这是一元“平均斜率等于某点切线斜率”的直接推广。例如 $f(x,y)=x^2+y^2$，$\boldsymbol{x}=(0,0)$、$\boldsymbol{y}=(1,1)$，左侧为 2；右侧为 $\nabla f(\theta,\theta)^{\top}(1,1)^{\top}=4\theta$，取 $\theta=1/2$ 即相等，中值点恰为线段中点。

局部 Lipschitz 性 定义 3.22已经给出 Lipschitz 连续与局部 Lipschitz 连续：存在常数 L，使输出距离不超过输入距离的 L 倍，局部情形允许常数随邻域改变。那里只说明了这种误差控制的含义，本小节的新任务是由导数求出这样的常数。

中值公式把有限增量写成某点梯度与位移的内积；若梯度的长度有统一上界，就能用输入距离的常数倍控制输出变化。以下距离都取欧氏范数。优化中常用这种控制由步长估计函数值的变化。

先看两个不依赖导数就能读出常数的例子。线性函数 $f(\boldsymbol{x})=\boldsymbol{a}^{\top}\boldsymbol{x}$ 满足 $|f(\boldsymbol{x})-f(\boldsymbol{y})|=|\boldsymbol{a}^{\top}(\boldsymbol{x}-\boldsymbol{y})|\le\|\boldsymbol{a}\|_2\|\boldsymbol{x}-\boldsymbol{y}\|_2$，Lipschitz 常数可取 $\|\boldsymbol{a}\|_2$，它恰是梯度的长度。欧氏范数 $f(\boldsymbol{x})=\|\boldsymbol{x}\|_2$ 由三角不等式满足 $|\|\boldsymbol{x}\|_2-\|\boldsymbol{y}\|_2|\le\|\boldsymbol{x}-\boldsymbol{y}\|_2$，常数为 1，尽管它在原点不可微。所以 Lipschitz 连续本身不要求处处可微。

要把梯度界转化为 Lipschitz 常数，两点之间的线段必须留在定义域内。若集合 D 中任意两点之间的线段都含于 D，就称 D 为凸集。在凸开集上，梯度长度的统一上界恰好就是 Lipschitz 常数。

定理 17.19 梯度有界与 Lipschitz 条件 设 $U\subseteq\mathbb{R}^d$ 为凸开集，$f:U\to\mathbb{R}$ 可微。则 f 在 U 上以 L 为 Lipschitz 常数，当且仅当 $\|\nabla f(\boldsymbol{x})\|_2\le L$ 对所有 $\boldsymbol{x}\in U$ 成立。

证明　若梯度长度不超过 L，任取 $\boldsymbol{x} \neq \boldsymbol{y}$，凸性保证线段 $[\boldsymbol{x}, \boldsymbol{y}] \subseteq U$。由中值公式与内积不等式，

$$|f(\boldsymbol{y}) - f(\boldsymbol{x})| = \left|\nabla f(\boldsymbol{\xi})^{\top}(\boldsymbol{y} - \boldsymbol{x})\right| \leq \|\nabla f(\boldsymbol{\xi})\|_2 \|\boldsymbol{y} - \boldsymbol{x}\|_2 \leq L\|\boldsymbol{y} - \boldsymbol{x}\|_2.$$

反过来，设 f 以 L 为 Lipschitz 常数。固定 $\boldsymbol{x}$，若 $\nabla f(\boldsymbol{x}) \neq \boldsymbol{0}$，取单位方向 $\boldsymbol{u} = \nabla f(\boldsymbol{x}) / \|\nabla f(\boldsymbol{x})\|_2$，则

$$\|\nabla f(\boldsymbol{x})\|_2 = D_{\boldsymbol{u}} f(\boldsymbol{x}) = \lim_{t \downarrow 0} \frac{f(\boldsymbol{x} + t\boldsymbol{u}) - f(\boldsymbol{x})}{t} \leq \lim_{t \downarrow 0} \frac{Lt}{t} = L.$$

梯度为零时不等式自然成立。 ■

几何上，若坡度处处不超过 L，沿直线走过距离 ρ，高度最多改变 $L\rho$；反过来，Lipschitz 常数也限制了每一点最陡方向的坡度。例如 $f(x, y) = \sin x + \cos y$ 满足 $\|\nabla f\|_2 = \sqrt{\cos^2 x + \sin^2 y} \leq \sqrt{2}$，所以它在整个平面上以 $\sqrt{2}$ 为 Lipschitz 常数。

定理中的凸性不能省略。在不凸的区域上，梯度可以处处很小，函数值却在两个很近的点之间相差很大。

示例 17.20　非凸区域上梯度有界而不 Lipschitz　取去掉负 x 轴的环形区域 $D = \{1 < \|\boldsymbol{x}\|_2 < 2\} \setminus \{(x, 0) : x < 0\}$，令 $f(\boldsymbol{x})$ 为点 $\boldsymbol{x}$ 的极角，取值于 $(-\pi, \pi)$。f 在 D 上可微，$\|\nabla f\|_2 = 1/r < 1$，坡度处处小于 1。但取负 x 轴两侧的点 $(-1.5, \pm\varepsilon)$，两点距离为 2ε，极角却分别接近 π 与 $-\pi$，相差接近 2π。令 $\varepsilon \to 0$，函数值之差与距离之比无界，所以 f 在 D 上不是 Lipschitz 函数。

连接这两点的直线段穿过被去掉的负 x 轴，不在 D 内，中值公式无法使用。D 内连接两点的路径必须绕过原点，长度远大于 2ε。可见梯度界只能沿含于定义域的线段转化为函数值之差的界。

局部情形不需要整个定义域凸。若 $f \in C^1(U)$，在每个基点附近取一个包含在 U 内的闭球。连续函数 $\|\nabla f\|_2$ 在这个闭有界集上有界（定理 3.24），因而在同心的开球上也有界。开球是凸开集，由定理 17.19，f 在这个开球上 Lipschitz 连续，所以 f 局部 Lipschitz 连续。各点的局部常数不一定有共同上界：$f(x, y) = x^2$ 连续可微，但 $\|\nabla f\|_2 = 2|x|$ 在全平面无界，因而它不是全域 Lipschitz 函数。

三种控制的强弱　至此出现了三种关于函数变化的结论，强度各不相同。连续只保证 $\boldsymbol{x} \to \boldsymbol{a}$ 时 $f(\boldsymbol{x}) \to f(\boldsymbol{a})$，不给出趋近的速度。可微给出渐近的线性近似：误差是 $o(\|\boldsymbol{h}\|_2)$，但对一个给定的有限步长，它不说明误差有

多大。梯度的统一界则沿含于定义域的线段控制有限距离上的变化，常数明确，却只估计变化的大小，不估计线性预测还差多少。

要估计一阶预测还差多少，需要把后两种结论结合起来，考察导数本身沿线段怎样变化。第 17.4节的 Taylor 公式用二阶导数描述这种变化；只用一阶导数的余项界，以及误差被放大多少倍的局部条件数，集中在第 20章讨论。

17.3 多元向量值函数的微分

前面每个输入只产生一个实数。本节研究同时产生 m 个输出分量的映射 $F : U \subseteq \mathbb{R}^d \to \mathbb{R}^m$，关心输入稍作改变时输出点整体怎样移动。

例如极坐标映射 $(r,\theta) \mapsto (r\cos\theta, r\sin\theta)$ 把两个参数变成平面上的点，神经网络的一层把输入向量变成另一个向量；参数曲线（$d=1$）与参数曲面（$d=2$、$m=3$）也是这种映射。输出只有有限个分量，所以可以逐个分量使用前面的结论。但每个分量仍要对全部输入方向整体扰动，不能用坐标切片代替各分量的全微分。本节先用一个线性映射定义整体可微并引入 Jacobian 矩阵，再给出复合映射的导数，最后用导数的算子范数估计有限增量。

17.3.1 Jacobian 矩阵

向量值函数由它的全部输出分量确定，因此按分量书写。

> **定义 17.21　多元向量值函数**　映射 $F : U \subseteq \mathbb{R}^d \to \mathbb{R}^m$ 称为多元向量值函数，写作 $F = (F_1, \dots, F_m)^{\top}$，其中每个 $F_i : U \to \mathbb{R}$ 为多元标量函数。

向量值函数的极限与连续性已在第 3.2.3节与第 3.2.4节定义，第 17.1.3节回顾了要点：输出点整体接近，等价于每个输出分量接近；每个分量的极限仍是对全部输入方向的联合极限。本节在连续性的基础上进一步研究线性近似。向量场是 $m=d$ 的特例，下面的结论对它同样适用。

微分与 Jacobian 矩阵　标量输出的全微分是到实数的线性映射，也称线性泛函。向量输出的全微分则要把输入扰动映射为 m 维输出扰动。有限维线性映射由矩阵表示，矩阵的每一行记录一个输出分量的系数。

定义 17.22　向量值函数的微分　设 U 开，$F:U\to\mathbb{R}^m$，$\boldsymbol{a}\in U$。若存在线性映射 $\mathrm{d}F_{\boldsymbol{a}}:\mathbb{R}^d\to\mathbb{R}^m$，记它在标准基下的矩阵为 $\boldsymbol{J}_F(\boldsymbol{a})\in\mathbb{R}^{m\times d}$，使

$$F(\boldsymbol{a}+\boldsymbol{h})=F(\boldsymbol{a})+\boldsymbol{J}_F(\boldsymbol{a})\boldsymbol{h}+o(\|\boldsymbol{h}\|_2),\tag{17.6}$$

则称 F 在 $\boldsymbol{a}$ 处可微，余项按输出欧氏范数理解。$\mathrm{d}F_{\boldsymbol{a}}(\boldsymbol{h})=\boldsymbol{J}_F(\boldsymbol{a})\boldsymbol{h}$ 称为 F 在 $\boldsymbol{a}$ 处的微分，矩阵 $\boldsymbol{J}_F(\boldsymbol{a})$ 称为Jacobian 矩阵 (Jacobian matrix)。

向量值函数可微当且仅当每个输出分量 F_i 可微。正向只需从向量余项取第 i 个分量，它的绝对值不超过向量余项的欧氏长度，于是得到 F_i 的标量展开；反向则把有限个分量的 $o(\|\boldsymbol{h}\|_2)$ 余项用欧氏范数合并，合并后仍是 $o(\|\boldsymbol{h}\|_2)$。由此，Jacobian 的第 i 行是分量梯度的转置 $\nabla F_i^{\top}$，第 i,j 个元素为 $\partial_j F_i$；微分若存在则唯一。C^k 向量值函数指所有输出分量都属于 C^k。

本书把输入、输出都写成列向量，因此 $\boldsymbol{J}_F(\boldsymbol{a})$ 是“输出维数 × 输入维数”的矩阵：第 i 行记录第 i 个输出对各输入的偏导数，$\boldsymbol{J}_F(\boldsymbol{a})\boldsymbol{h}$ 的形状为 $(m\times d)(d\times 1)=m\times 1$，与输出一致。$m=1$ 时 Jacobian 是 $1\times d$ 的行向量 $\nabla f(\boldsymbol{a})^{\top}$，梯度则是列向量，二者互为转置。

Jacobian 矩阵的几何意义　按行看，Jacobian 记录各输出分量的梯度；按列看，它记录各输入坐标对输出点的推动。第 j 列

$$\boldsymbol{J}_F(\boldsymbol{a})\boldsymbol{e}_j=(\partial_j F_1,\dots,\partial_j F_m)^{\top}$$

表示：只把第 j 个输入增加一个很小的量 t 时，输出点大约移动这个向量的 t 倍。一般扰动 $\boldsymbol{h}=\sum_j h_j\boldsymbol{e}_j$ 的一阶效果，就是这些列按 h_j 加权求和。对 $d=m=2$，由此得到局部伸缩的图像。以 $\boldsymbol{a}$ 为角、边长为 ε 的小正方形由 $\varepsilon\boldsymbol{e}_1,\varepsilon\boldsymbol{e}_2$ 张成，它的像近似是由 $\varepsilon\boldsymbol{J}_F\boldsymbol{e}_1,\varepsilon\boldsymbol{J}_F\boldsymbol{e}_2$ 张成的平行四边形。行列式的绝对值是线性映射对面积的缩放倍数（第 1.3.1节），所以像的面积约为 $|\det\boldsymbol{J}_F(\boldsymbol{a})|\varepsilon^2$；行列式的符号说明局部是否翻转了定向。

极坐标映射是这种局部伸缩的一个具体例子。

示例 17.23　极坐标映射的 Jacobian 矩阵　考虑极坐标映射

$$P(r,\theta)=(r\cos\theta,r\sin\theta)^{\top}.$$

逐个输出分量求偏导，得到

$$\boldsymbol{J}_P(r,\theta)=\begin{bmatrix}\cos\theta & -r\sin\theta\\ \sin\theta & r\cos\theta\end{bmatrix}$$

$$\det \boldsymbol{J}_P = r\cos^2\theta + r\sin^2\theta = r.$$

第一列是单位径向向量：r 增加 $\mathrm{d}r$，点沿射线向外移动 $\mathrm{d}r$。第二列长度为 r、沿圆周切向：θ 增加 $\mathrm{d}\theta$，点沿半径为 r 的圆移动约 $r\,\mathrm{d}\theta$。因此参数平面中面积为 $\mathrm{d}r\,\mathrm{d}\theta$ 的小矩形，变成面积约为 $r\,\mathrm{d}r\,\mathrm{d}\theta$ 的小扇形块。

离原点越远，同样的角度增量扫过的弧越长，面积放大越多。第 21.3节的区域积分换元就用这个倍数校正面积。

对一般的非线性映射，小网格块的像是弯边块，线性近似把它换成平行四边形。图 17.3画出了这种对应。图中 $\det J_T(a) = 1\times0.6 - 0.25\times0.3 = 0.525$，所以绿色小方块的像面积约为原面积的一半。

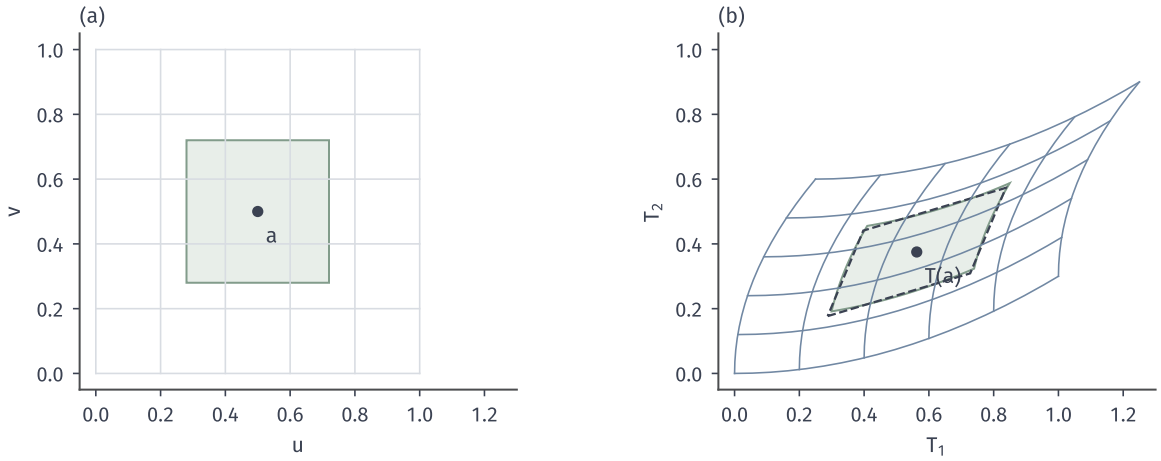


图 17.3　取 $T(u,v)=(u+v^2/4,\ 0.6v+0.3u^2)$，$a=(0.5,0.5)$。(a) 输入网格及绿色小方块。(b) 非线性像为弯边块，黑虚线为 $T(a)+J_T(a)(h,k)^{\top}$ 给出的平行四边形；$J_T(a)=\left[\begin{smallmatrix}1 & 0.25\\ 0.3 & 0.6\end{smallmatrix}\right]$。有限块不与线性像完全重合，缩小扰动后才由可微余项控制差异。

输入、输出维数不同时，同一个原则给出非方阵的 Jacobian。

示例 17.24　空间螺旋线的 Jacobian 矩阵　令 $\boldsymbol{\gamma}(t)=(\cos t,\sin t,t)^{\top}$，$t\in\mathbb{R}$，输入一维、输出三维。逐分量求导得

$$\boldsymbol{J}_{\boldsymbol{\gamma}}(t)=\begin{bmatrix}-\sin t\\ \cos t\\ 1\end{bmatrix}\in\mathbb{R}^{3\times1}.$$

> 它把参数增量 s 映为 $s\boldsymbol{J}_{\boldsymbol{\gamma}}(t)$：点沿速度向量 $\boldsymbol{\gamma}'(t)$ 移动。这一列就是曲线的切向量，长度为 $\sqrt{2}$，说明参数每增加一个单位，点约移动 $\sqrt{2}$ 的距离。

螺旋线的 Jacobian 不是方阵，没有行列式可言，局部伸缩由切向量的长度描述。极坐标与螺旋线说明，“微分是线性映射”这一原则在不同输入、输出维数下给出形状不同的矩阵，不能默认 Jacobian 是方阵或有行列式。梯度映射 $\boldsymbol{x} \mapsto \nabla f(\boldsymbol{x})$ 本身也是从 $\mathbb{R}^d$ 到 $\mathbb{R}^d$ 的向量值映射，第 17.4节将研究它的微分，并由此得到 Hessian 矩阵。

Jacobian 矩阵的计算　计算 Jacobian 矩阵时，先把每个输出分量当作标量函数求偏导，再按行排列；排好后核对矩阵形状是否为“输出维数 × 输入维数”。例如 $F(x,y) = (x^2 + xy,\, y^2)^{\top}$ 的 Jacobian 为

$$\boldsymbol{J}_F(x,y) = \begin{bmatrix} 2x + y & x \\ 0 & 2y \end{bmatrix}.$$

在 $(1,2)$ 处，它把扰动 $(h,k)^{\top}$ 的一阶影响写成 $(4h + k, 4k)^{\top}$。第一行说明第一个输出同时受两个输入推动，第二行说明第二个输出只随 y 变化；两列分别记录沿 x、沿 y 移动时输出点的位移方向。

再看机器学习中常用的一个向量值映射。它把任意一组实数变成总和为 1 的正权重：先取指数，再除以共同的总和。这就是 n 维**归一化指数映射**（softmax），分类模型常用它把各类别的得分变成概率。对正整数 n 和 $\boldsymbol{z} \in \mathbb{R}^n$，令

$$s_i(\boldsymbol{z}) = \frac{e^{z_i}}{\sum_{k=1}^{n} e^{z_k}}$$

$$i = 1, \dots, n.$$

记分母为 $Z = \sum_k e^{z_k}$，它对 z_j 的偏导数为 e^{z_j}。对分子 e^{z_i} 求偏导，$i = j$ 时得 e^{z_i}，$i \neq j$ 时得 0，记为 $\mathbb{I}\{i = j\}e^{z_i}$。商法则给出

$$\frac{\partial s_i}{\partial z_j} = \frac{\mathbb{I}\{i = j\}e^{z_i} Z - e^{z_i} e^{z_j}}{Z^2} = s_i\big(\mathbb{I}\{i = j\} - s_j\big).$$

因此整个 Jacobian 矩阵为

$$\boldsymbol{J}_{\boldsymbol{s}}(\boldsymbol{z}) = \operatorname{diag}(\boldsymbol{s}) - \boldsymbol{s}\boldsymbol{s}^{\top}. \tag{17.7}$$

这里 $\operatorname{diag}(\boldsymbol{s})$ 表示以 $s_1, \dots, s_n$ 为对角元、其他元素为零的对角矩阵。

当 $n \geq 2$ 时，对角项 $s_i(1 - s_i)$ 为正，描述提高 z_i 对自身分量的影响。非对角项 $-s_i s_j$ 为负，它来自共同分母：提高一个得分会压低其余分量。当 $n = 1$ 时输出恒为 1，Jacobian 为零。

每行元素之和为 $s_i - s_i \sum_j s_j = 0$。这与给所有 z_i 加同一常数不改变输出相符：沿方向 $(1,\dots,1)^{\top}$ 的一阶变化为零。

在最简单的情形中，可以用数值核对式 (17.7)给出的线性近似。

示例 17.25　二维 softmax 的 Jacobian 矩阵　取 $n = 2$、$\boldsymbol{z} = \mathbf{0}$，则 $\boldsymbol{s} = (1/2, 1/2)^{\top}$，由式 (17.7)，

$$\boldsymbol{J}_{\boldsymbol{s}}(\mathbf{0}) = \begin{bmatrix} 1/2 & 0 \\ 0 & 1/2 \end{bmatrix} - \begin{bmatrix} 1/4 & 1/4 \\ 1/4 & 1/4 \end{bmatrix} = \begin{bmatrix} 1/4 & -1/4 \\ -1/4 & 1/4 \end{bmatrix}.$$

把 z_1 提高 0.1，线性近似给出 $\boldsymbol{s}$ 的增量约为

$$\boldsymbol{J}_{\boldsymbol{s}}(\mathbf{0})(0.1, 0)^{\top} = (0.025, -0.025)^{\top},$$

即 $s_1 \approx 0.525$、$s_2 \approx 0.475$。实际值为 $s_1 = e^{0.1}/(e^{0.1}+1) \approx 0.52498$、$s_2 \approx 0.47502$。

线性近似与实际值只差约 2×10^{-5}，远小于输入改变量 0.1；两个分量的增量一正一负、总和为零，与 $s_1 + s_2$ 恒为 1 相符。

17.3.2 微分的运算法则

与标量情形一样，复杂映射的 Jacobian 可以由简单映射的 Jacobian 组合得到。各法则以运算有定义为前提：输出形状相同的向量值函数可以相加、相减，任何向量值函数都可以数乘；复合则要求前一映射的输出落在后一映射的定义域内。两个向量之间的乘法需要先指定含义；下面先处理线性运算与复合，再用链式法则处理内积等乘法结构。

和、差与数乘的微分　若 $F, H : U \to \mathbb{R}^m$ 在 $\boldsymbol{a}$ 处可微，对每个输出分量分别使用标量的和、差与数乘法则，再把各分量的结果按行排回矩阵，得到

$$\boldsymbol{J}_{F \pm H}(\boldsymbol{a}) = \boldsymbol{J}_F(\boldsymbol{a}) \pm \boldsymbol{J}_H(\boldsymbol{a})$$
$$\boldsymbol{J}_{cF}(\boldsymbol{a}) = c\boldsymbol{J}_F(\boldsymbol{a}),$$

其中 c 是固定实数。相加的输出形状以及两个 Jacobian 的形状必须分别一致。

复合函数的链式法则　复合映射 $G \circ F$ 先用 F 把输入变成中间量，再用 G 把中间量变成输出。输入的小扰动 $\boldsymbol{h}$ 先被 F 变成中间量的扰动，一阶上约为 $\boldsymbol{J}_F\boldsymbol{h}$；这个扰动再被 G 变成输出扰动，一阶上约为 $\boldsymbol{J}_G(\boldsymbol{J}_F\boldsymbol{h})$。所以复合映射的 Jacobian 是两个 Jacobian 按计算顺序的乘积。与一元情形一样，这项规则称为**链式法则**（chain rule）。

定理 17.26　向量值函数的链式法则　设 $U \subseteq \mathbb{R}^d$、$V \subseteq \mathbb{R}^m$ 开，$F : U \to V$ 在 $\boldsymbol{a}$ 处可微，$G : V \to \mathbb{R}^p$ 在 $F(\boldsymbol{a})$ 处可微，则 $G \circ F$ 在 $\boldsymbol{a}$ 处可微，且

$$\boldsymbol{J}_{G\circ F}(\boldsymbol{a}) = \boldsymbol{J}_G(F(\boldsymbol{a}))\boldsymbol{J}_F(\boldsymbol{a}). \tag{17.8}$$

证明　记 $\boldsymbol{A} = \boldsymbol{J}_F(\boldsymbol{a})$、$\boldsymbol{B} = \boldsymbol{J}_G(F(\boldsymbol{a}))$。由 F 可微，中间量的增量为

$$\boldsymbol{k} = F(\boldsymbol{a}+\boldsymbol{h}) - F(\boldsymbol{a}) = \boldsymbol{A}\boldsymbol{h} + o(\|\boldsymbol{h}\|_2),$$

故 $\|\boldsymbol{k}\|_2 \le \|\boldsymbol{A}\boldsymbol{h}\|_2 + o(\|\boldsymbol{h}\|_2) = O(\|\boldsymbol{h}\|_2)$：中间量的扰动与原扰动同阶。代入 G 的一阶展开，

$$G(F(\boldsymbol{a})+\boldsymbol{k}) - G(F(\boldsymbol{a})) = \boldsymbol{B}\boldsymbol{k} + o(\|\boldsymbol{k}\|_2) = \boldsymbol{B}\boldsymbol{A}\boldsymbol{h} + \boldsymbol{B}\,o(\|\boldsymbol{h}\|_2) + o(\|\boldsymbol{k}\|_2).$$

右侧第二项中，矩阵 $\boldsymbol{B}$ 至多把长度放大固定倍数，所以仍是 $o(\|\boldsymbol{h}\|_2)$；第三项因 $\|\boldsymbol{k}\|_2 = O(\|\boldsymbol{h}\|_2)$ 也是 $o(\|\boldsymbol{h}\|_2)$（$\boldsymbol{k} = \boldsymbol{0}$ 时外层余项为零）。于是复合增量等于 $\boldsymbol{B}\boldsymbol{A}\boldsymbol{h}$ 加上 $o(\|\boldsymbol{h}\|_2)$，这正是复合函数的可微定义。 ■

式 (17.8)中的矩阵形状为 $(p\times m)(m\times d) = p\times d$，反向相乘往往没有定义。即使两个次序都有定义，矩阵乘法一般也不交换，不能按标量经验调换因子。用局部伸缩的语言说，复合映射在一点附近的伸缩等于两步伸缩依次作用。方阵情形下，由行列式的乘法公式，面积缩放倍数也相乘。

内积、范数平方与复合二次型　链式法则把复杂表达式拆成一串简单映射；计算时要分清哪些对象是向量值中间变量，哪些是最后的标量。设 $F, G : U \to \mathbb{R}^m$ 在 $\boldsymbol{a}$ 处可微。内积 $\phi(\boldsymbol{x}) = F(\boldsymbol{x})^{\top} G(\boldsymbol{x})$ 是映射 $\boldsymbol{x} \mapsto (F(\boldsymbol{x}), G(\boldsymbol{x})) \in \mathbb{R}^{2m}$ 与双线性函数 $b(\boldsymbol{u},\boldsymbol{w}) = \boldsymbol{u}^{\top}\boldsymbol{w}$ 的复合。b 在 $(\boldsymbol{u},\boldsymbol{w})$ 处的精确增量为

$$b(\boldsymbol{u}+\boldsymbol{p}, \boldsymbol{w}+\boldsymbol{r}) - b(\boldsymbol{u},\boldsymbol{w}) = \boldsymbol{p}^{\top}\boldsymbol{w} + \boldsymbol{u}^{\top}\boldsymbol{r} + \boldsymbol{p}^{\top}\boldsymbol{r},$$

末项满足 $|\boldsymbol{p}^{\top}\boldsymbol{r}| \le \|\boldsymbol{p}\|_2\|\boldsymbol{r}\|_2 \le \tfrac{1}{2}(\|\boldsymbol{p}\|_2^2 + \|\boldsymbol{r}\|_2^2)$，是联合扰动的二次量，所以 b 可微，微分为 $(\boldsymbol{p},\boldsymbol{r}) \mapsto \boldsymbol{p}^{\top}\boldsymbol{w} + \boldsymbol{u}^{\top}\boldsymbol{r}$。由链式法则，

$$\mathrm{d}\phi_{\boldsymbol{a}}(\boldsymbol{h}) = \big(\boldsymbol{J}_F(\boldsymbol{a})\boldsymbol{h}\big)^{\top} G(\boldsymbol{a}) + F(\boldsymbol{a})^{\top}\boldsymbol{J}_G(\boldsymbol{a})\boldsymbol{h}$$

$$\nabla\phi(\boldsymbol{a}) = \boldsymbol{J}_F(\boldsymbol{a})^{\top} G(\boldsymbol{a}) + \boldsymbol{J}_G(\boldsymbol{a})^{\top} F(\boldsymbol{a}).$$

取 $G = F$，得到范数平方的梯度 $\nabla\|F\|_2^2 = 2\boldsymbol{J}_F^{\top}F$。对固定的对称矩阵 $\boldsymbol{S}$，复合二次型 $F(\boldsymbol{x})^{\top}\boldsymbol{S}F(\boldsymbol{x})$ 是 F 与二次型 $\boldsymbol{y} \mapsto \boldsymbol{y}^{\top}\boldsymbol{S}\boldsymbol{y}$ 的复合，由式 (17.3)和链式法则，梯度为 $2\boldsymbol{J}_F^{\top}\boldsymbol{S}F$。

范数本身要单独判断。在 $\boldsymbol{x} \neq \boldsymbol{0}$ 处，$\|\boldsymbol{x}\|_2 = \sqrt{\|\boldsymbol{x}\|_2^2}$ 是正数上可微的平方根与光滑函数的复合，梯度为 $\boldsymbol{x}/\|\boldsymbol{x}\|_2$。在原点，沿直线 $t\boldsymbol{v}$（$\boldsymbol{v} \neq \boldsymbol{0}$）得到 $|t|\|\boldsymbol{v}\|_2$，双侧方向导数不存在，所以不可微。范数平方在原点光滑，并不能推出范数在原点可微：平方根在 0 处没有有限导数，链式法则的条件不满足。

链式法则的一个常见用法是：先用向量值映射得到中间量，再把中间量变成一个标量，然后求这个标量对原输入的梯度。

示例 17.27　从中间向量求回复合目标的梯度　令

$$F(x_1, x_2) = (x_1^2, x_1 x_2, x_2)^{\top}$$
$$\ell(\boldsymbol{y}) = \frac{1}{2}(y_1^2 + y_2^2 + y_3^2).$$

F 从二维输入产生三维中间量，ℓ 再把三维中间量变成一个数，复合得到 $L = \ell \circ F : \mathbb{R}^2 \to \mathbb{R}$。$\ell$ 的 Jacobian 是 1×3 行向量 $\nabla \ell(\boldsymbol{y})^{\top}$，由链式法则，$L$ 的 Jacobian 为 $\nabla \ell(F(\boldsymbol{x}))^{\top} \boldsymbol{J}_F(\boldsymbol{x})$；转置后得到列向量梯度

$$\nabla L(\boldsymbol{x}) = \boldsymbol{J}_F(\boldsymbol{x})^{\top} \nabla \ell\big(F(\boldsymbol{x})\big).$$

这里出现转置，是因为梯度按列向量书写，而链式法则中的 ℓ 导数是行向量。本例中

$$\boldsymbol{J}_F = \begin{bmatrix} 2x_1 & 0 \\ x_2 & x_1 \\ 0 & 1 \end{bmatrix}$$
$$\nabla \ell(\boldsymbol{y}) = \boldsymbol{y}.$$

在 $\boldsymbol{x} = (1, 2)^{\top}$ 处，$\boldsymbol{y} = (1, 2, 2)^{\top}$，链式法则给出

$$\nabla L(1, 2) = \begin{bmatrix} 2 & 2 & 0 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix} = \begin{bmatrix} 6 \\ 4 \end{bmatrix}.$$

也可以把复合函数直接展开为 $L(x_1, x_2) = \frac{1}{2}(x_1^4 + x_1^2 x_2^2 + x_2^2)$，求偏导得到 $\nabla L = (2x_1^3 + x_1 x_2^2,\ x_1^2 x_2 + x_2)^{\top}$，在同一点仍为 $(6, 4)^{\top}$。矩阵形状 $(2 \times 3)(3 \times 1) = 2 \times 1$ 也核对了梯度传递的次序。

两种计算得到同一个梯度。链式形式保留了中间映射，各层的导数可以分别计算、分别复用。

梯度沿复合的传递与伴随　例子中的转置不只是书写约定，它是第 3.6节的伴随。设 $F : U \subseteq \mathbb{R}^d \to \mathbb{R}^m$ 在 $\boldsymbol{a}$ 处可微，g 在 $F(\boldsymbol{a})$ 的邻域内有定义并

在 $F(\boldsymbol{a})$ 处可微，输入、输出空间各取一个内积。链式法则写成线性映射的复合 $\mathrm{d}(g\circ F)_{\boldsymbol{a}} = \mathrm{d}g_{F(\boldsymbol{a})}\circ \mathrm{d}F_{\boldsymbol{a}}$。对任意 $\boldsymbol{h}$，依次使用梯度的定义与伴随的定义式 (3.19)，

$$\mathrm{d}(g\circ F)_{\boldsymbol{a}}(\boldsymbol{h}) = \big\langle \nabla g(F(\boldsymbol{a})), \mathrm{d}F_{\boldsymbol{a}}(\boldsymbol{h})\big\rangle = \big\langle \mathrm{d}F_{\boldsymbol{a}}^{\star}\nabla g(F(\boldsymbol{a})), \boldsymbol{h}\big\rangle,$$

其中第一个内积在输出空间中计算，第二个在输入空间中计算。由梯度的唯一性，

$$\nabla(g\circ F)(\boldsymbol{a}) = \mathrm{d}F_{\boldsymbol{a}}^{\star}\,\nabla g(F(\boldsymbol{a})). \tag{17.9}$$

微分 $\mathrm{d}F_{\boldsymbol{a}}$ 把输入扰动向前推到输出端，伴随则把输出端的梯度拉回输入端。两端都取标准欧氏内积时，伴随的矩阵是 $\boldsymbol{J}_F(\boldsymbol{a})^{\top}$，式 (17.9)就是上例中的 $\boldsymbol{J}_F^{\top}\nabla \ell$；两端分别取 Gram 矩阵为 $\boldsymbol{M}_V, \boldsymbol{M}_W$ 的内积时，由式 (3.20)，伴随的矩阵为 $\boldsymbol{M}_V^{-1}\boldsymbol{J}_F(\boldsymbol{a})^{\top}\boldsymbol{M}_W$，与式 (17.5)相容。这样，矩阵乘法、泛函配对与梯度的传递是同一件事的三种写法；矩阵函数的梯度和隐函数的导数都沿用这一规则。

17.3.3　向量增量的估计

标量函数的中值公式在线段上找到一个点，用那里的梯度精确表示增量。向量值函数不能照搬：各输出分量的一元中值点可能不同，没有一个共同的点代表整个向量增量。例如 $F(t) = (\cos t, \sin t)^{\top}$ 在 $[0, 2\pi]$ 上走完一整圈，$F(2\pi) - F(0) = \boldsymbol{0}$，但速度 $F'(t) = (-\sin t, \cos t)^{\top}$ 长度恒为 1，不存在 τ 使 $F(2\pi) - F(0) = 2\pi F'(\tau)$。因此改为估计增量的长度，或者把增量写成沿线段的积分。

导数的算子范数　对标量函数，导数的绝对值说明输入的小变化被放大多少倍。对向量输出，同一个线性映射在不同方向上的放大倍数可能不同，于是取其中最大的一个。第 3.3.4节已经定义线性映射的算子范数，并证明有限维时它有限且可以取到。用于微分时，它度量最坏输入方向上的一阶放大倍数：

$$\|\mathrm{d}F_{\boldsymbol{a}}\| = \max_{\|\boldsymbol{h}\|\le 1} \|\mathrm{d}F_{\boldsymbol{a}}(\boldsymbol{h})\|.$$

两端都取欧氏范数时，它就是 Jacobian 矩阵的谱范数 $\|\boldsymbol{J}_F(\boldsymbol{a})\|_2$，并满足 $\|\boldsymbol{J}_F(\boldsymbol{a})\boldsymbol{h}\|_2 \le \|\boldsymbol{J}_F(\boldsymbol{a})\|_2\|\boldsymbol{h}\|_2$。标量函数时 $\|\nabla f(\boldsymbol{a})^{\top}\|_2 = \|\nabla f(\boldsymbol{a})\|_2$，这就是上一节中梯度长度的角色。计算时先给出对全部单位向量成立的上界，再找出达到上界的方向。

示例 17.28　对角矩阵的算子范数　令 $\boldsymbol{A}=\operatorname{diag}(2,1)$，它把第一坐标放大两倍、第二坐标保持不变。对单位向量 $\boldsymbol{h}$，

$$\|\boldsymbol{A}\boldsymbol{h}\|_2^2 = 4h_1^2 + h_2^2 \le 4(h_1^2+h_2^2) = 4,$$

且 $\boldsymbol{h}=\boldsymbol{e}_1$ 时取等号，故 $\|\boldsymbol{A}\|_2 = 2$。

又如旋转矩阵不改变任何向量的长度，算子范数为 1。

用算子范数估计增量长度，就不再需要各分量共用一个中值点。所需条件是 G 在含整条线段的开集上连续可微。

定理 17.29　向量值函数的中值估计　设 $U\subseteq\mathbb{R}^r$ 开，$G:U\to\mathbb{R}^s$ 连续可微，且 $[\boldsymbol{y}',\boldsymbol{y}]\subset U$，则

$$\|G(\boldsymbol{y})-G(\boldsymbol{y}')\|_2 \le \sup_{0\le t\le 1}\big\|\boldsymbol{J}_G\big(\boldsymbol{y}'+t(\boldsymbol{y}-\boldsymbol{y}')\big)\big\|_2\,\|\boldsymbol{y}-\boldsymbol{y}'\|_2. \tag{17.10}$$

证明　思路是把向量增量投影到它自己的方向上，变成一个标量函数的增量，再对标量函数用中值定理。若 $\boldsymbol{u}=G(\boldsymbol{y})-G(\boldsymbol{y}')\neq\boldsymbol{0}$，取单位向量 $\boldsymbol{v}=\boldsymbol{u}/\|\boldsymbol{u}\|_2$，并沿线段定义标量函数 $\phi(t)=\boldsymbol{v}^{\top}G(\boldsymbol{y}'+t(\boldsymbol{y}-\boldsymbol{y}'))$。由链式法则，$\phi'(t)=\boldsymbol{v}^{\top}\boldsymbol{J}_G(\boldsymbol{y}'+t(\boldsymbol{y}-\boldsymbol{y}'))(\boldsymbol{y}-\boldsymbol{y}')$；中值定理给出某个 $\tau\in(0,1)$，使

$$\|\boldsymbol{u}\|_2 = \boldsymbol{v}^{\top}\boldsymbol{u} = \phi(1)-\phi(0) = \boldsymbol{v}^{\top}\boldsymbol{J}_G(\boldsymbol{y}'+\tau(\boldsymbol{y}-\boldsymbol{y}'))(\boldsymbol{y}-\boldsymbol{y}').$$

对右侧先用内积不等式并注意 $\|\boldsymbol{v}\|_2=1$，再用谱范数的上界，便得到式 (17.10)；$\boldsymbol{u}=\boldsymbol{0}$ 时该界直接成立。 ∎

向量增量的积分表示　中值估计只给出长度的上界。在同样的条件下，还可以把整个向量增量精确写出。记 $\boldsymbol{p}=\boldsymbol{y}-\boldsymbol{y}'$。对每个分量 G_i，一元函数 $t\mapsto G_i(\boldsymbol{y}'+t\,\boldsymbol{p})$ 在 $[0,1]$ 上连续可微，由式 (17.2)，导数为 $\nabla G_i(\boldsymbol{y}'+t\,\boldsymbol{p})^{\top}\boldsymbol{p}$。逐分量使用一元微积分基本定理，得到

$$G(\boldsymbol{y})-G(\boldsymbol{y}') = \int_0^1 \boldsymbol{J}_G(\boldsymbol{y}'+t\,\boldsymbol{p})\,\boldsymbol{p}\,\mathrm{d}t, \tag{17.11}$$

其中向量的积分按分量理解。这个等式不需要共同的中间点：各分量的变化率沿整条线段累计。对连续的向量值函数 $\boldsymbol{w}:[0,1]\to\mathbb{R}^s$，有

$$\Big\|\int_0^1 \boldsymbol{w}(t)\,\mathrm{d}t\Big\|_2 \le \int_0^1 \|\boldsymbol{w}(t)\|_2\,\mathrm{d}t.$$

记左侧的积分为 $\boldsymbol{u}$，由积分的线性、单调性与 Cauchy–Schwarz 不等式，$\|\boldsymbol{u}\|_2^2 = \int_0^1 \boldsymbol{u}^{\top}\boldsymbol{w}(t)\,\mathrm{d}t \le \|\boldsymbol{u}\|_2 \int_0^1 \|\boldsymbol{w}(t)\|_2\,\mathrm{d}t$，$\boldsymbol{u} \neq \boldsymbol{0}$ 时除以 $\|\boldsymbol{u}\|_2$ 即得。把它用于式 (17.11)，再次得到式 (17.10)。积分形式的长处在于，可以先从被积函数中扣除一个固定的线性项，第 20章据此估计一阶近似的余项（第 20.1.2节）。

Lipschitz 估计与压缩　若定义域为凸开集，且 Jacobian 的谱范数在全域不超过同一个有限常数 L，则由式 (17.10)，G 以 L 为 Lipschitz 常数：任意两点的像之间的距离至多是原距离的 L 倍。在局部球上使用同样的界，就得到局部版本。特别地，若 Jacobian 的谱范数在某个闭球内不超过常数 $q < 1$，映射就把球内任意两点间的距离缩小到至多 q 倍，称为压缩。但压缩界本身不保证迭代留在这个球内，也不单独给出不动点：还要检查映射把球映入自身，并借有限维空间的完备性（定理 3.28）取得迭代的极限。第 19章证明隐函数定理时依次核对这三点。

17.4　高阶微分与极值判别

一阶微分用切平面描述局部变化，却看不出曲面向哪边弯：碗底、山顶和马鞍点处的切平面都是水平的。切平面遗漏的部分中，最先出现的是弯曲。把第 17.3节的向量值微分用于梯度映射，就能研究一阶变化本身怎样变化，从而描述弯曲。

前面已建立的多线性映射、二次型和谱判别，在这里分别用于表示高阶导数、衡量二阶项和判断局部形状。本节先把二阶偏导数集中为 Hessian 矩阵并解释为二阶微分，再借一元 Taylor 公式建立二阶近似，最后据此判断驻点的类型。

17.4.1　二阶偏导数、Hessian 与高阶微分

一阶偏导数本身仍是多元标量函数，可以再求偏导。这里记 $f_{x_i x_j} = \partial_j(\partial_i f)$，即先对 x_i、再对 x_j 求导。f_{xx} 描述 x 方向切片的斜率沿 x 方向怎样变化，即该切片的弯曲。混合偏导数 f_{xy} 描述沿 y 方向移动时 x 方向的斜率怎样变化，即曲面的扭转。

对 $f(x,y) = x^2 + xy + y^2$，有 $f_{xx} = 2$、$f_{xy} = f_{yx} = 1$、$f_{yy} = 2$。又如 $f(x,y) = xy$：x 方向切片的斜率是 y，向北每走一单位，这个斜率就增加 1，故 $f_{xy} = 1$，而 $f_{xx} = f_{yy} = 0$。它的每条坐标切片都是直线，曲面却是扭曲的。这两个例子中都有 $f_{xy} = f_{yx}$。一般函数的混合偏导数能否交换次序，则需要额外条件。

混合偏导数的交换 先看一个反例：两个次序的混合偏导数都存在，却不相等。

示例 17.30 混合偏导数与求导次序有关 令 $f(0,0)=0$，非原点处令

$$f(x,y)=\frac{xy(x^2-y^2)}{x^2+y^2}.$$

对 $y\neq 0$，因为 $f(0,y)=0$，

$$f_x(0,y)=\lim_{h\to 0}\frac{f(h,y)}{h}=\lim_{h\to 0}\frac{y(h^2-y^2)}{h^2+y^2}=-y;$$

又 f 在 x 轴上恒为 0，故 $f_x(0,0)=0$，公式 $f_x(0,y)=-y$ 在 $y=0$ 时也成立。同样算得 $f_y(x,0)=x$ 对所有 x 成立。于是

$$f_{xy}(0,0)=\frac{\mathrm{d}}{\mathrm{d}y}(-y)\Big|_{y=0}=-1$$
$$f_{yx}(0,0)=\frac{\mathrm{d}}{\mathrm{d}x}x\Big|_{x=0}=1,$$

两个次序给出不同结果。

下面的定理说明，混合偏导数在基点连续时两种次序一定相同。因此本例的混合偏导数不可能都在原点连续。

定理 17.31 混合偏导数的交换 设 f 在 $\boldsymbol{a}$ 的某个开邻域内有一阶偏导数 $\partial_i f,\partial_j f$，混合偏导数 $\partial_j\partial_i f,\partial_i\partial_j f$ 在该邻域存在并在 $\boldsymbol{a}$ 处连续，则

$$\partial_j\partial_i f(\boldsymbol{a})=\partial_i\partial_j f(\boldsymbol{a}).$$

特别地，C^2 函数的混合偏导数处处可以交换。

证明 固定其他坐标，只需讨论二元函数在 (a,b) 处的情形。对小的非零 h,k 考察小矩形四个顶点上的二阶差分

$$\Delta(h,k)=f(a+h,b+k)-f(a+h,b)-f(a,b+k)+f(a,b).$$

它可以按两种方式分组：先比较上下两边的差，或先比较左右两边的差，两种分组各给出一个混合偏导数。

令 $\phi(x) = f(x, b+k) - f(x, b)$，则 $\Delta = \phi(a+h) - \phi(a)$。先对 ϕ 用一元中值定理，得到 $\Delta = h\phi'(\xi) = h[f_x(\xi, b+k) - f_x(\xi, b)]$；再对 $y \mapsto f_x(\xi, y)$ 使用一次中值定理，得到

$$\Delta = h[f_x(\xi, b+k) - f_x(\xi, b)] = hk f_{xy}(\xi, \eta),$$

其中 ξ 在 $a, a+h$ 之间、η 在 $b, b+k$ 之间。改用 $\psi(y) = f(a+h, y) - f(a, y)$ 先沿 y 方向拆分，同样得到 $\Delta = hk f_{yx}(\xi', \eta')$。于是 $f_{xy}(\xi, \eta) = f_{yx}(\xi', \eta')$。令 $h, k \to 0$，两个中间点都趋于 (a, b)，连续性使两种混合偏导数在该点相等。 ■

示例 17.30说明，只有混合偏导数存在而缺少连续性时，结论可能失败。

Hessian 矩阵　把全部二阶偏导数排成一个方阵，就得到记录二阶信息的矩阵。它的行、列分别对应先后两次求导的输入坐标。

定义 17.32　Hessian 矩阵　若 $f : U \to \mathbb{R}$ 在 $\boldsymbol{x}$ 附近有一阶偏导数，且各 $\partial_j \partial_i f(\boldsymbol{x})$ 存在，则称

$$\nabla^2 f(\boldsymbol{x}) = \left[\partial_j \partial_i f(\boldsymbol{x})\right]_{i,j=1}^{d}$$

为 f 在该点的Hessian 矩阵（Hessian matrix）。

第 i 行是第 i 个偏导数 $\partial_i f$ 的偏导数向量的转置，所以 Hessian 可以理解为“梯度的梯度”。与一阶情形一样，二阶偏导数存在还不保证梯度映射 ∇f 有统一的线性近似。二阶可微指 ∇f 本身作为向量值映射可微（定义 17.22）。

Hessian 是梯度映射的 Jacobian　设 $f \in C^2(U)$。梯度映射 $\nabla f : U \to \mathbb{R}^d$ 的第 i 个分量是 $\partial_i f$，它的各偏导数 $\partial_j \partial_i f$ 连续，由定理 17.11逐分量可微，所以 ∇f 作为向量值映射可微，C^2 是二阶可微的充分条件。按 Jacobian 的约定，第 (i, j) 个元素是第 i 个分量对第 j 个输入的偏导数 $\partial_j \partial_i f$，因此在标准欧氏坐标下

$$\boldsymbol{J}_{\nabla f}(\boldsymbol{x}) = \nabla^2 f(\boldsymbol{x}).$$

Hessian 因而有两种读法：它是二阶偏导数表，也是梯度映射的微分的矩阵；后一种读法说明它描述基点移动时梯度向量怎样变化。由定理 17.31，C^2 时它还是对称矩阵。对 $x^2 + xy + y^2$，Hessian 就是

$$\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

一元函数的二阶导数描述曲线向上还是向下弯。多元函数可以沿每个方向分别看：若 $f \in C^2$，沿直线 $t \mapsto f(\boldsymbol{x}+t\boldsymbol{v})$ 求两次导数，在 $t=0$ 处得到

$$\boldsymbol{v}^{\top} \nabla^2 f(\boldsymbol{x}) \boldsymbol{v} = \sum_{i=1}^{d} \sum_{j=1}^{d} \partial_j \partial_i f(\boldsymbol{x}) v_i v_j .$$

这一计算的依据见定理 17.35的证明。这个二次型衡量沿方向 $\boldsymbol{v}$ 截出的切片曲线的弯曲：为正时向上弯，为负时向下弯。

二次函数的 Hessian 可以直接读出。对

$$f(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^{\top} \boldsymbol{A} \boldsymbol{x} + \boldsymbol{b}^{\top} \boldsymbol{x} + c,$$

只有 $\boldsymbol{A}$ 的对称部分影响函数值，因为 $\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x}$ 与其转置 $\boldsymbol{x}^{\top}\boldsymbol{A}^{\top}\boldsymbol{x}$ 相等。令 $\boldsymbol{H} = (\boldsymbol{A}+\boldsymbol{A}^{\top})/2$, 由式 (17.3), $\nabla f(\boldsymbol{x}) = \boldsymbol{H}\boldsymbol{x}+\boldsymbol{b}$, 再求一次导得 $\nabla^2 f(\boldsymbol{x}) = \boldsymbol{H}$。二次函数的 Hessian 是常数矩阵，各处弯曲相同。

例如 $\boldsymbol{H} = \operatorname{diag}(2, 100)$ 时，方向二次型为 $2v_1^2 + 100v_2^2$。沿两个坐标方向都向上弯，但第二个方向的二阶变化率是第一个的 50 倍。函数图像是一个狭长的山谷：等值曲线是椭圆，沿 x_1 方向的半轴是沿 x_2 方向的 $\sqrt{50} \approx 7.1$ 倍。若改为 $\operatorname{diag}(2, -100)$，两个坐标方向的弯曲方向相反，图像是马鞍形。

这些情形可以按二次型的符号分类。第 1.2.1.1节已定义正定与半正定矩阵，这里把它们用于 Hessian，并补充不定的情形。对实对称矩阵 $\boldsymbol{H}$，若每个非零 $\boldsymbol{v}$ 都有 $\boldsymbol{v}^{\top}\boldsymbol{H}\boldsymbol{v} > 0$，称 $\boldsymbol{H}$ 正定；若只要求 $\boldsymbol{v}^{\top}\boldsymbol{H}\boldsymbol{v} \geq 0$，则称半正定。把不等号反向得到负定与半负定。若既有使二次型为正的方向，又有使它为负的方向，则称矩阵不定。这些名称说明各方向曲率的符号：正定对应各方向都向上弯的碗形，负定对应倒扣的碗，不定对应马鞍。

判断定性需要检查整个二次型，不能只看对角元素。

示例 17.33　用二次型判断 Hessian 的定性　先看

$$\boldsymbol{H} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

把它的二次型配方，

$$\boldsymbol{v}^{\top}\boldsymbol{H}\boldsymbol{v} = 2v_1^2 + 2v_1 v_2 + 2v_2^2 = (v_1+v_2)^2 + v_1^2 + v_2^2,$$

$\boldsymbol{v} \neq \boldsymbol{0}$ 时后两项之和已经为正，所以二次型恒正，$\boldsymbol{H}$ 正定。再看

$$\begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}.$$

> 它的两个对角元也都为正，但非对角元更大。沿 $\boldsymbol{v}=(1,-1)^{\top}$，二次型为 $1-4+1=-2<0$；沿 $\boldsymbol{v}=(1,1)^{\top}$，二次型为 $6>0$。两个方向符号相反，所以这个矩阵不定。

第二个矩阵的对角元只说明沿坐标轴向上弯；沿对角线 $y=-x$，曲面却向下弯。

高阶微分的多线性形式　Hessian 不只是一张二阶偏导数表，它还可以同时作用于两个不同的扰动方向。对固定的 $\boldsymbol{h}$，一阶变化 $\mathrm{d}f_{\boldsymbol{x}}(\boldsymbol{h})=\nabla f(\boldsymbol{x})^{\top}\boldsymbol{h}$ 是基点 $\boldsymbol{x}$ 的函数；沿方向 $\boldsymbol{k}$ 求它的全微分，由 $\boldsymbol{J}_{\nabla f}=\nabla^2 f$ 得到

$$D^2 f_{\boldsymbol{x}}[\boldsymbol{h},\boldsymbol{k}]=\mathrm{d}\big(\boldsymbol{y}\mapsto\nabla f(\boldsymbol{y})^{\top}\boldsymbol{h}\big)_{\boldsymbol{x}}(\boldsymbol{k})=\boldsymbol{h}^{\top}\nabla^2 f(\boldsymbol{x})\boldsymbol{k}.$$

它对两个方向分别线性，且因混合偏导数相等而对称，是第 2.3节意义下的对称双线性形式，Hessian 就是它在标准基下的系数矩阵。$D^2 f_{\boldsymbol{x}}[\boldsymbol{h},\boldsymbol{k}]$ 记录沿 $\boldsymbol{h}$ 的变化率怎样随沿 $\boldsymbol{k}$ 的移动而改变；把两个方向都取成 $\boldsymbol{h}$，就得到 Taylor 公式中的二次项。

更一般地，可以把 $\boldsymbol{x}\mapsto\mathrm{d}f_{\boldsymbol{x}}$ 看作取值于线性泛函空间的映射。这个空间是有限维的，取坐标后就是偏导数向量；对它再求微分得到二阶微分，逐次进行就得到高阶微分。f 为 C^r 时，

$$D^r f_{\boldsymbol{x}}[\boldsymbol{h}_1,\dots,\boldsymbol{h}_r]=\sum_{i_1,\dots,i_r=1}^{d}\frac{\partial^r f}{\partial x_{i_1}\cdots\partial x_{i_r}}(\boldsymbol{x})(h_1)_{i_1}\cdots(h_r)_{i_r}.$$

有限和中的每一项对每个方向分别线性，所以这定义了一个 r 重线性形式。混合偏导数可以交换，使它对方向的次序对称。r 阶偏导数组成的坐标数组，就是这个多线性形式在标准基下的系数，与第 2.3节多线性映射的坐标表示相同，不需要另建一套数组式的导数定义。

例如 $f(x,y)=x^2y$ 在 $(1,2)$ 处的 Hessian 为

$$\begin{bmatrix}4 & 2\\ 2 & 0\end{bmatrix}.$$

方向 $\boldsymbol{h}=(h_1,h_2)^{\top}$ 上的二次变化为 $4h_1^2+4h_1h_2$。其中的混合项说明，两个坐标同时变化时，不能把两条坐标轴上的一元展开简单相加。

二阶导数界与导数的 Lipschitz 性　二阶微分还能控制一阶导数本身变化多快。一阶近似的误差取决于导数沿扰动线段的变化，第 20章估计余项时需要这样的控制。设 $F:U\to\mathbb{R}^m$ 属于 C^2，即各分量的二阶偏导数连续。

把 $\boldsymbol{x}\mapsto \boldsymbol{J}_F(\boldsymbol{x})$ 看作取值于矩阵空间的映射，它沿方向 $\boldsymbol{k}$ 的一阶变化是矩阵 $\sum_{l} k_l\,\partial_l \boldsymbol{J}_F(\boldsymbol{x})$；再让它作用于 $\boldsymbol{h}$，定义

$$D^2F_{\boldsymbol{x}}[\boldsymbol{h},\boldsymbol{k}] = \Big(\sum_{l=1}^{d} k_l\,\partial_l \boldsymbol{J}_F(\boldsymbol{x})\Big)\boldsymbol{h} \in \mathbb{R}^m,$$

它的第 i 个分量是 $\boldsymbol{h}^{\top}\nabla^2 F_i(\boldsymbol{x})\boldsymbol{k}$。用

$$\|D^2F_{\boldsymbol{x}}\| = \max_{\|\boldsymbol{h}\|_2\le 1,\ \|\boldsymbol{k}\|_2\le 1} \|D^2F_{\boldsymbol{x}}[\boldsymbol{h},\boldsymbol{k}]\|_2$$

度量二阶作用的大小，最大值由连续函数在闭有界集上取到。由齐次性，$\|D^2F_{\boldsymbol{x}}[\boldsymbol{h},\boldsymbol{k}]\|_2 \le \|D^2F_{\boldsymbol{x}}\|\|\boldsymbol{h}\|_2\|\boldsymbol{k}\|_2$。标量函数时，这个量就是 $\|\nabla^2 f(\boldsymbol{x})\|_2$。

定理 17.34　二阶导数界给出导数的 Lipschitz 界　设 $U\subseteq\mathbb{R}^d$ 为凸开集，$F:U\to\mathbb{R}^m$ 属于 C^2，且 $\|D^2F_{\boldsymbol{z}}\|\le M$ 对所有 $\boldsymbol{z}\in U$ 成立，则

$$\|\boldsymbol{J}_F(\boldsymbol{y})-\boldsymbol{J}_F(\boldsymbol{x})\|_2 \le M\|\boldsymbol{y}-\boldsymbol{x}\|_2 \qquad (\boldsymbol{x},\boldsymbol{y}\in U).$$

证明　固定单位向量 $\boldsymbol{h}$，令 $G(\boldsymbol{z})=\boldsymbol{J}_F(\boldsymbol{z})\boldsymbol{h}$。$G$ 的第 i 个分量是 $\nabla F_i(\boldsymbol{z})^{\top}\boldsymbol{h}$，连续可微，且 G 的 Jacobian 作用于 $\boldsymbol{k}$ 恰给出 $D^2F_{\boldsymbol{z}}[\boldsymbol{h},\boldsymbol{k}]$。凸性保证线段 $[\boldsymbol{x},\boldsymbol{y}]\subset U$。记 $\boldsymbol{p}=\boldsymbol{y}-\boldsymbol{x}$，对 G 使用式 (17.11)并取范数，

$$\begin{aligned}\big\|(\boldsymbol{J}_F(\boldsymbol{y})-\boldsymbol{J}_F(\boldsymbol{x}))\boldsymbol{h}\big\|_2 &= \Big\|\int_0^1 D^2F_{\boldsymbol{x}+t\boldsymbol{p}}[\boldsymbol{h},\boldsymbol{p}]\,\mathrm{d}t\Big\|_2\\ &\le \int_0^1 M\|\boldsymbol{p}\|_2\,\mathrm{d}t = M\|\boldsymbol{p}\|_2.\end{aligned}$$

对全部单位向量 $\boldsymbol{h}$ 取最大值，左侧就成为 $\|\boldsymbol{J}_F(\boldsymbol{y})-\boldsymbol{J}_F(\boldsymbol{x})\|_2$。 ∎

于是二阶导数的统一界给出 Jacobian 的 Lipschitz 常数。第 20.1.2节将证明，只要 Jacobian 满足这样的 Lipschitz 型界，一阶近似的余项就不超过 $\frac{L}{2}\|\boldsymbol{h}\|_2^2$；本定理是取得该条件的一种充分办法，那里的余项估计本身不要求二阶导数存在。

17.4.2　多元 Taylor 展开与余项

一元 Taylor 公式用导数构造多项式近似。把多个坐标同时改变的位移看成一条线段上的参数变化，就能沿这条线段使用一元 Taylor 公式。所得公式的一次项给出切平面，二次项是 Hessian 二次型，补上曲面的弯曲。沿线段使用带 Lagrange 余项的一元公式，得到中间点形式的余项；再利用二阶偏导数在基点的连续性，得到小量形式的余项。

定理 17.35　多元标量函数的二阶 Taylor 公式　设 $f \in C^2(U), U \subseteq \mathbb{R}^d$ 开，线段 $[\boldsymbol{x}, \boldsymbol{x}+\boldsymbol{h}] \subset U$。若 $\boldsymbol{h} \neq \boldsymbol{0}$，则存在 $\theta \in (0,1)$ 使

$$f(\boldsymbol{x}+\boldsymbol{h}) = f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})^{\top}\boldsymbol{h} + \frac{1}{2}\boldsymbol{h}^{\top}\nabla^2 f(\boldsymbol{x}+\theta\boldsymbol{h})\boldsymbol{h}. \tag{17.12}$$

对固定 $\boldsymbol{x} \in U$，当 $\boldsymbol{h} \to \boldsymbol{0}$ 时还有

$$f(\boldsymbol{x}+\boldsymbol{h}) = f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})^{\top}\boldsymbol{h} + \frac{1}{2}\boldsymbol{h}^{\top}\nabla^2 f(\boldsymbol{x})\boldsymbol{h} + o(\|\boldsymbol{h}\|_2^2). \tag{17.13}$$

证明　令 $\phi(t) = f(\boldsymbol{x}+t\boldsymbol{h})$。由方向导数公式，$\phi'(t) = \nabla f(\boldsymbol{x}+t\boldsymbol{h})^{\top}\boldsymbol{h} = \sum_i \partial_i f(\boldsymbol{x}+t\boldsymbol{h}) h_i$。每个 $\partial_i f$ 属于 C^1，因而可微；对它再用一次方向导数公式，$\frac{\mathrm{d}}{\mathrm{d}t}\partial_i f(\boldsymbol{x}+t\boldsymbol{h}) = \sum_j \partial_j\partial_i f(\boldsymbol{x}+t\boldsymbol{h}) h_j$。相加得 $\phi''(t) = \sum_{i,j} \partial_j\partial_i f(\boldsymbol{x}+t\boldsymbol{h}) h_i h_j = \boldsymbol{h}^{\top}\nabla^2 f(\boldsymbol{x}+t\boldsymbol{h})\boldsymbol{h}$。对 ϕ 在 $[0,1]$ 上使用带 Lagrange 余项的一元 Taylor 定理，$\phi(1) = \phi(0) + \phi'(0) + \frac{1}{2}\phi''(\theta)$，即得第一式。

第二式要把中间点处的 Hessian 换成基点处的 Hessian，并估计替换误差。$\theta \in (0,1)$ 可以随 $\boldsymbol{h}$ 变化，但中间点 $\boldsymbol{x}+\theta\boldsymbol{h}$ 到 $\boldsymbol{x}$ 的距离不超过 $\|\boldsymbol{h}\|_2$；Hessian 各元素又在 $\boldsymbol{x}$ 处连续，所以 $\boldsymbol{h} \to \boldsymbol{0}$ 时 $\|\nabla^2 f(\boldsymbol{x}+\theta\boldsymbol{h}) - \nabla^2 f(\boldsymbol{x})\|_F \to 0$。对任意方阵 $\boldsymbol{B}$，对 $\sum_{i,j} B_{i,j} h_i h_j$ 使用有限和的 Cauchy–Schwarz 不等式，得到 $|\boldsymbol{h}^{\top}\boldsymbol{B}\boldsymbol{h}| \le \|\boldsymbol{B}\|_F \|\boldsymbol{h}\|_2^2$。取 $\boldsymbol{B}$ 为两个 Hessian 之差，替换产生的误差不超过 $\frac{1}{2}\|\boldsymbol{B}\|_F\|\boldsymbol{h}\|_2^2 = o(\|\boldsymbol{h}\|_2^2)$，得到第二式。 ∎

中间点 $\boldsymbol{x}+\theta\boldsymbol{h}$ 的位置一般无法确定。若希望保留整条线段上的曲率信息，可以改用一元 Taylor 公式的积分余项形式：对在 $[0,1]$ 上二阶连续可微的一元函数 ϕ，有

$$\phi(1) = \phi(0) + \phi'(0) + \int_0^1 (1-t)\phi''(t)\,\mathrm{d}t,$$

它由对 ϕ' 在 $[0,1]$ 上用一元微积分基本定理，再分部积分得到，可参考卷一第 7 章“一元函数的积分”。在同一 C^2 条件下，令 $\phi(t) = f(\boldsymbol{x}+t\boldsymbol{h})$，代入定理证明中算出的 ϕ' 与 ϕ''，得到

$$f(\boldsymbol{x}+\boldsymbol{h}) = f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})^{\top}\boldsymbol{h} + \int_0^1 (1-t)\,\boldsymbol{h}^{\top}\nabla^2 f(\boldsymbol{x}+t\boldsymbol{h})\boldsymbol{h}\,\mathrm{d}t.$$

权重 $1-t$ 在起点 $t=0$ 处最大、在终点处为零，所以越靠近位移起点的曲率对有限增量贡献越多。这个表达式与式 (17.12)描述同一个有限变化，只是用加权平均代替了中间点。

局部展开与有限误差 式 (17.13)只是局部结论：小 $o(\|\boldsymbol{h}\|_2^2)$ 说明步长趋零时二阶模型的误差相对更小，却不给出某个指定有限扰动的数值误差界。要得到这样的界，需要在整条线段上控制更高阶的变化。若 f 在线段的一个开邻域内属于 C^3，同样的计算给出 $\phi'''(t) = D^3 f_{\boldsymbol{x}+t\boldsymbol{h}}[\boldsymbol{h},\boldsymbol{h},\boldsymbol{h}]$；若沿线段 $|D^3 f_{\boldsymbol{x}+t\boldsymbol{h}}[\boldsymbol{h},\boldsymbol{h},\boldsymbol{h}]| \le M_3\|\boldsymbol{h}\|_2^3$，一元 Taylor 公式便给出

$$\left| f(\boldsymbol{x}+\boldsymbol{h}) - f(\boldsymbol{x}) - \nabla f(\boldsymbol{x})^{\top}\boldsymbol{h} - \frac{1}{2}\boldsymbol{h}^{\top}\nabla^2 f(\boldsymbol{x})\boldsymbol{h} \right| \le \frac{M_3}{6}\|\boldsymbol{h}\|_2^3,$$

即二阶截断误差具有三阶量级。仅凭一点处的二阶导数得不到这样的界。

下面用一个具体函数比较一阶近似与二阶近似的误差。

示例 17.36　指数函数的二阶 Taylor 近似 令 $f(x,y) = e^{x+y}$。在原点，函数值为 1，梯度为 $(1,1)^{\top}$，Hessian 的各元素均为 1，对应的二次型为 $h^2 + 2hk + k^2 = (h+k)^2$。由式 (17.13)，

$$e^{h+k} = 1 + h + k + \frac{1}{2}(h+k)^2 + o(h^2+k^2).$$

取 $h = k = 0.1$，实际值 $e^{0.2} \approx 1.22140$。切平面给出 1.2，误差约 0.021；加上二次项给出 1.22，误差降到约 0.0014。沿这条线段 $D^3 f[\boldsymbol{h},\boldsymbol{h},\boldsymbol{h}] = e^{t(h+k)}(h+k)^3 \le e^{0.2}\times 0.008$，上面的三阶界给出误差不超过约 0.0016，与实际误差同量级。

一次项描述切平面，二次项补上沿位移方向的弯曲，所以加入二次项后误差明显减小。本例的二次项是 $(h+k)^2$，含有混合项 $2hk$：坐标之间的相互作用不能通过分别对 h、k 做一元展开再简单相加来恢复。更高阶的项由多线性微分作用于重复的方向给出。

17.4.3 驻点的二阶判别

Taylor 公式把函数增量写成梯度项、Hessian 二次型与高阶余项之和。于是梯度与 Hessian 的条件可以转化为关于极值的结论。先回顾极值的定义。若存在 $\boldsymbol{x}^{\star}$ 的一个邻域，使其中定义域内的点的函数值都不小于 $f(\boldsymbol{x}^{\star})$，就称 $\boldsymbol{x}^{\star}$ 为局部极小点；若邻域中其他点的函数值都严格更大，则称为严格局部极小点。局部极大点与严格局部极大点用反向不等式定义。本小节只考察开集内部的点，不涉及约束。

局部极值的一阶必要条件 一元函数在内部极值点处导数为零（Fermat 条件）。把多元函数限制在任意一条过极值点的直线上，该点仍是所得一元函数的极值点，所以每个方向上的导数都必须为零。几何上，极值点处的切平面是水平的。

定理 17.37　局部极值的一阶必要条件　设 $f : U \to \mathbb{R}$ 在开集 U 内的点 $\boldsymbol{x}^\star$ 处可微，且该点为局部极小点或局部极大点，则

$$\nabla f(\boldsymbol{x}^\star) = \boldsymbol{0}. \tag{17.14}$$

证明　对每个方向 $\boldsymbol{v}$，一元函数 $t \mapsto f(\boldsymbol{x}^\star + t\boldsymbol{v})$ 在 0 处有局部极值，由 Fermat 条件和方向导数公式，导数 $\nabla f(\boldsymbol{x}^\star)^{\top}\boldsymbol{v} = 0$。取各坐标方向 $\boldsymbol{v} = \boldsymbol{e}_j$，即得全部偏导数为零。 ∎

梯度为零的点称为驻点。驻点未必是极值点：$x^2 - y^2$ 在原点梯度为零，但沿 x 轴原点是最低点，沿 y 轴却是最高点。要区分这些情形，需要二阶信息。

局部极值的二阶必要条件　在极小点处，函数不能沿任何方向向下弯，否则沿该方向稍走一步，函数值就会变小。若函数在该点附近有连续的二阶偏导数，这一要求就是 Hessian 二次型的符号条件。

定理 17.38　局部极值的二阶必要条件　设 f 在 $\boldsymbol{x}^\star$ 附近属于 C^2。若 $\boldsymbol{x}^\star$ 为内部局部极小点，则

$$\boldsymbol{v}^{\top}\nabla^2 f(\boldsymbol{x}^\star)\boldsymbol{v} \geq 0 \qquad (\boldsymbol{v} \in \mathbb{R}^d), \tag{17.15}$$

即 Hessian 半正定；内部局部极大点对应 Hessian 半负定。

证明　对每个 $\boldsymbol{v}$，$\phi(t) = f(\boldsymbol{x}^\star + t\boldsymbol{v})$ 在 0 处有局部极小，由一元极值的二阶必要条件，$\phi''(0) \geq 0$；而定理 17.35的证明已算出 $\phi''(0)$ 正是所述二次型。 ∎

必要条件不能单独决定驻点类型。一元函数 x^4、$-x^4$ 及 x^3 在 0 处一阶、二阶导数都为零，却分别为极小、极大和非极值。多元函数在二次型为零的方向上同样要检查更高阶项。

驻点的二阶充分条件　反过来，若各非零方向的二次型都严格为正，函数在驻点处沿所有方向都向上弯。Taylor 余项是更高阶的小量，不会改变充分小扰动下函数增量的符号，于是驻点是严格极小点。这里要求正定而不只是半正定：每个方向都要有正曲率，而不只是没有负曲率。

定理 17.39 驻点的 Hessian 判别 设 f 在 $\boldsymbol{x}^\star$ 附近属于 C^2，且 $\nabla f(\boldsymbol{x}^\star)=\mathbf{0}$。若 Hessian 正定，则 $\boldsymbol{x}^\star$ 是严格局部极小点；若负定，则为严格局部极大点；若不定，则任意小邻域都存在函数值大于及小于 $f(\boldsymbol{x}^\star)$ 的点。

证明 记 $\boldsymbol{H}_\star=\nabla^2 f(\boldsymbol{x}^\star)$，先设它正定。余项估计需要一个对所有方向共同的正下界，而每个方向的二次型为正并不直接给出这样的下界。为此在闭有界的单位球面上考察连续函数 $\boldsymbol{v}\mapsto \boldsymbol{v}^{\top}\boldsymbol{H}_\star\boldsymbol{v}$。由定理 3.24，它取到最小值

$$\lambda=\min_{\|\boldsymbol{v}\|_2=1}\boldsymbol{v}^{\top}\boldsymbol{H}_\star\boldsymbol{v}>0;$$

最小值在某个单位向量处取得，正定性保证这个值为正。把 $\boldsymbol{v}$ 按 $\boldsymbol{H}_\star$ 的标准正交特征基展开为 $\sum_i c_i\boldsymbol{u}_i$（第 4章的实对称谱分解），得 $\boldsymbol{v}^{\top}\boldsymbol{H}_\star\boldsymbol{v}=\sum_i \lambda_i c_i^2\ge \lambda_{\min}\sum_i c_i^2$，取 $\boldsymbol{v}$ 为相应特征向量时取等号，所以 λ 就是 $\boldsymbol{H}_\star$ 的最小特征值。把任意非零 $\boldsymbol{h}$ 写成 $\|\boldsymbol{h}\|_2\boldsymbol{v}$，$\boldsymbol{v}$ 为单位向量，就得到 $\boldsymbol{h}^{\top}\boldsymbol{H}_\star\boldsymbol{h}\ge\lambda\|\boldsymbol{h}\|_2^2$。

再处理中间点处的 Hessian。由 Hessian 矩阵的连续性，存在一个小球，使球内每点 $\boldsymbol{x}$ 满足 $\|\nabla^2 f(\boldsymbol{x})-\boldsymbol{H}_\star\|_F\le\lambda/2$。对球内的非零 $\boldsymbol{h}$，式 (17.12)给出某个中间点 $\boldsymbol{\xi}=\boldsymbol{x}^\star+\theta\boldsymbol{h}$，利用 $\nabla f(\boldsymbol{x}^\star)=\mathbf{0}$ 与 Taylor 公式证明中的不等式 $|\boldsymbol{h}^{\top}\boldsymbol{B}\boldsymbol{h}|\le\|\boldsymbol{B}\|_F\|\boldsymbol{h}\|_2^2$，

$$\begin{aligned} f(\boldsymbol{x}^\star+\boldsymbol{h})-f(\boldsymbol{x}^\star) &= \frac{1}{2}\boldsymbol{h}^{\top}\boldsymbol{H}_\star\boldsymbol{h}+\frac{1}{2}\boldsymbol{h}^{\top}\bigl(\nabla^2 f(\boldsymbol{\xi})-\boldsymbol{H}_\star\bigr)\boldsymbol{h}\\ &\ge \frac{1}{2}\lambda\|\boldsymbol{h}\|_2^2-\frac{1}{2}\cdot\frac{\lambda}{2}\|\boldsymbol{h}\|_2^2=\frac{\lambda}{4}\|\boldsymbol{h}\|_2^2>0, \end{aligned}$$

故 $\boldsymbol{x}^\star$ 是严格局部极小点。负定情形对 $-f$ 使用同一论证，给出严格局部极大点。

若 Hessian 不定，分别选取使二次型为正和为负的方向 $\boldsymbol{v}_+,\boldsymbol{v}_-$。沿固定方向 $\boldsymbol{v}$ 把扰动写成 $t\boldsymbol{v}$，由式 (17.13)，

$$f(\boldsymbol{x}^\star+t\boldsymbol{v})-f(\boldsymbol{x}^\star)=\frac{t^2}{2}\boldsymbol{v}^{\top}\boldsymbol{H}_\star\boldsymbol{v}+o(t^2).$$

充分小的非零 t 不会改变非零二次项的符号，因此沿 $\boldsymbol{v}_+$ 函数值增加，沿 $\boldsymbol{v}_-$ 函数值减小，任意小邻域内两种点都存在。 ∎

不定情形中的驻点称为**鞍点**（saddle point），因为它像马鞍的中心：沿一个方向是最低点，沿另一个方向是最高点。例如 $f(x,y)=x^2-y^2$ 的 Hessian 为 $\operatorname{diag}(2,-2)$，原点就是鞍点。

若 Hessian 仅半正定或半负定，且在某些非零方向上二次型为零，二阶判据可能没有结论，必须查看更高阶项或函数的其他结构。上述条件还假定点位于开集内部。边界上的极小点梯度可以不为零，例如 $f(x)=x$ 在 $[0,1]$ 上的最小点 0。受约束的问题需要可行方向与乘子条件，可参考卷五第 5 章“约束优化与对偶”。

综合一阶与二阶条件，判别驻点分两步：先解 $\nabla f=\mathbf{0}$ 找出驻点，再在每个驻点检查 Hessian 的定性。

示例 17.40　驻点的分类　令 $f(x,y)=x^3-3x+y^2$。梯度 $\nabla f=(3x^2-3,\,2y)^{\top}$ 为零当且仅当 $x=\pm1$、$y=0$，所以驻点是 $(1,0)$ 与 $(-1,0)$。Hessian 为 $\operatorname{diag}(6x,2)$。在 $(1,0)$ 处它是 $\operatorname{diag}(6,2)$，正定，故 $(1,0)$ 是严格局部极小点，$f(1,0)=-2$。在 $(-1,0)$ 处它是 $\operatorname{diag}(-6,2)$，不定，故 $(-1,0)$ 是鞍点：沿 x 方向，x^3-3x 在 -1 处取局部极大；沿 y 方向，y^2 在 0 处取极小。

这个例子也说明局部极小不等于全局最小：沿负 x 轴 $f\to-\infty$，该函数在整个平面上没有最小值。

图 17.4对照二阶判别可以决定的形状，以及 Hessian 退化时仍需继续检查的情形。

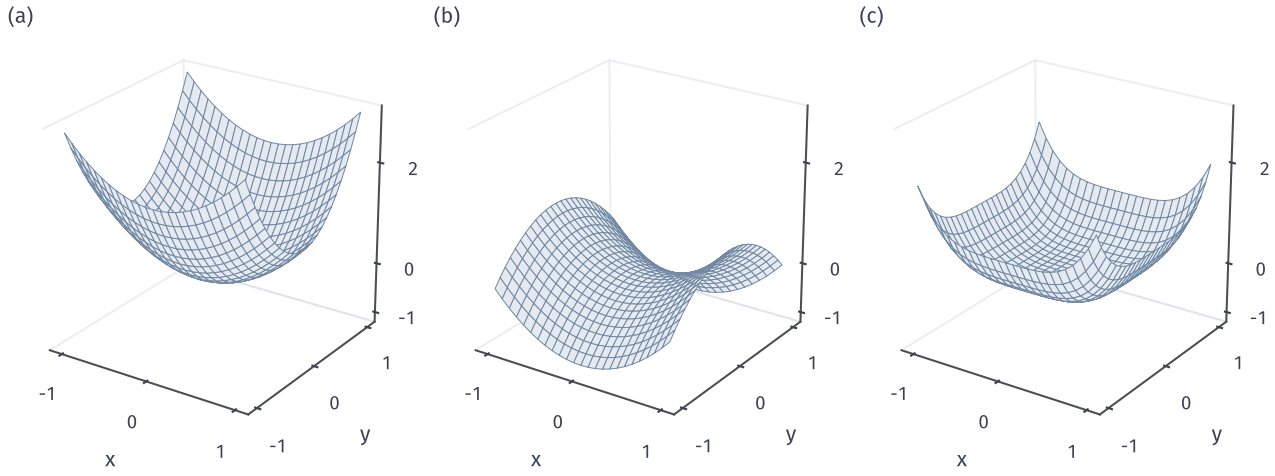


图 17.4　同一 $[-1,1]^2$ 范围和纵轴尺度下，三面分别为 x^2+2y^2、x^2-y^2、x^4+y^4。原点的 Hessian 依次为正定、不定、零矩阵；前两者给严格极小与鞍点，第三者虽严格极小却不能由正定判据推出。零 Hessian 也可能没有极值，例如前述 x^3，故退化不是一种确定分类。

17.5 本章小结

本章的对象是位置上的量：标量场在每点给出一个数，向量场在每点给出一个与位置同维的向量，一般向量值函数的输出维数可以不同。它们的极限与连续性按输入、输出的范数理解，输出可以逐分量判断，输入的多个坐标却不能拆开逐个检查；沿两条路径得到不同极限能否定极限存在，只查若干条路径则不能证明它存在。

偏导数和方向导数只考察固定的直线。可微要求所有小扰动共用一个线性近似，包括方向随步长改变的扰动；这个近似由偏导数唯一确定。偏导数存在、全部方向导数存在或函数连续，都不单独保证可微；即使全部方向导数组成一个线性映射，仍须满足统一的余项条件。偏导数连续是方便的充分条件，但不是必要条件。

全微分是输入扰动上的线性泛函，梯度是它在所选内积下的表示向量。改变内积会改变梯度的坐标和最陡上升方向，全微分本身不变。沿含于定义域的线段，中值公式把梯度的大小化为有限变化的界；在凸开集上，梯度长度的统一上界恰好就是 Lipschitz 常数，凸性不能省略。

输出为向量时，微分由 Jacobian 矩阵表示，它的行是各分量的梯度，列是各输入坐标对输出点的推动。复合映射的 Jacobian 按计算顺序相乘，标量目标的梯度则由微分的伴随传回输入端。向量增量没有共同的中值点，改用沿线段的积分表示，并由导数的算子范数控制长度。

把微分再用于梯度，得到 Hessian 与二阶 Taylor 公式。混合偏导数在连续时可以交换，C^2 函数的 Hessian 因而对称。在开集内的驻点处，Hessian 正定、负定或不定分别对应严格极小、严格极大和鞍点；半定而退化的情形需要更高阶的信息，边界点和受约束的问题也不在这一判别的范围内。

这些结论都是局部的：可微只保证余项是 $o(\|\boldsymbol{h}\|)$，不说明给定步长下误差有多大。矩阵自变量的微分公式、隐式方程确定的解，以及导数怎样控制误差放大和一阶预测的精度，依次在后面三章展开。

第 18 章

矩阵函数的微分

机器学习中的参数常排成矩阵，例如线性层的权重或协方差矩阵。损失是这些矩阵的标量函数，求逆、相乘等运算又产生矩阵输出。本章要回答：以矩阵为自变量时，微分是什么形状的对象；标量输出的梯度怎样读出；乘法、求逆、行列式与对数行列式这些常用运算的微分公式是什么，在哪里成立。

原则上可以把矩阵拉直成长向量，再用第 17章的结论。但保留矩阵形状，乘法次序与迹的结构更清楚，结果也能直接写成矩阵表达式。矩阵空间是有限维线性空间，所以本章不建立新的微分理论，而是把已有的全微分、链式法则与 Riesz 表示用于矩阵，集中处理三件事：矩阵的形状，乘法不交换，以及对称、正定等结构约束。

第一节说明矩阵变量的微分与 Frobenius 梯度，并区分全部扰动与结构受限的扰动。后四节依次处理基本运算、求逆、行列式和对数行列式。每种运算都先确定定义域与输入输出，再由增量的一阶项读出微分并验证可微性；能写出精确增量的运算，就用同一个代数展开完成这两件事。

本章只建立微分公式与梯度。这些公式给出的一阶预测在有限扰动下有多准、误差被放大多少，留到第 20章统一估计。本章用到第 1章的迹、行列式与逆矩阵，第 3章的 Frobenius 内积与 Riesz 表示，以及第 14章逆矩阵的有限扰动界。

18.1 矩阵微分与梯度

$m \times n$ 矩阵输入可以看成 mn 个实数坐标，$r \times s$ 矩阵输出可以看成 rs 个实数分量。按固定顺序（例如逐列）把矩阵元素排成长向量，矩阵空间就等同于欧氏坐标空间；第 1.3.2节的 Frobenius 内积与范数 $\langle \boldsymbol{A}, \boldsymbol{B} \rangle_F = \operatorname{tr}(\boldsymbol{A}^\top \boldsymbol{B}) = \sum_{i,j} A_{i,j} B_{i,j}$，正是拉直后向量的欧氏内积与欧氏范数。本章的定义域 $\mathcal{U}$ 都是全矩阵空间 $\mathbb{R}^{m \times n}$ 中的开集，基点 $\boldsymbol{X} \in \mathcal{U}$，因此全部充分小的同形扰动都可以使用。

设 $\Phi : \mathcal{U} \to \mathbb{R}^{r\times s}$。若存在矩阵空间之间的线性映射 $\mathrm{d}\Phi_{\boldsymbol{X}} : \mathbb{R}^{m\times n} \to \mathbb{R}^{r\times s}$，使

$$\Phi(\boldsymbol{X}+\boldsymbol{H}) = \Phi(\boldsymbol{X}) + \mathrm{d}\Phi_{\boldsymbol{X}}(\boldsymbol{H}) + o(\|\boldsymbol{H}\|_F),$$

余项按输出的 Frobenius 范数度量，则称 Φ 在 $\boldsymbol{X}$ 处可微，$\mathrm{d}\Phi_{\boldsymbol{X}}$ 为其微分。这就是向量值可微性按矩阵形状重排后的写法，计算时常写 $\mathrm{d}\Phi = \mathrm{d}\Phi_{\boldsymbol{X}}(\mathrm{d}\boldsymbol{X})$。$\mathrm{d}\Phi_{\boldsymbol{X}}$ 是从输入扰动空间到输出空间的线性映射，拉直后它的矩阵是 $rs\times mn$ 的 Jacobian，一般不能写成一个与 $\boldsymbol{X}$ 同形的矩阵。

还要分清两类“矩阵的函数”。$\boldsymbol{X}\mapsto\boldsymbol{X}^{-1}$、$\boldsymbol{X}\mapsto\boldsymbol{X}^{2}$ 这类映射按矩阵运算定义，输出的每个元素一般依赖输入的许多元素；逐元素作用（例如对每个元素分别取指数）则把各元素分别送入一元函数，微分只在对应位置上相乘。第 6.5节由标量函数沿谱构造的矩阵函数 $f(\boldsymbol{S})$ 属于前一类，但只是以矩阵为输入的映射中的一种；它与逐元素作用不能混为一谈，研究 $\boldsymbol{S}\mapsto f(\boldsymbol{S})$ 的微分时，扰动一般也不保持原来的特征方向。

输入变量决定扰动的形状 同一个表达式随所选变量不同，微分的输入也不同。固定 $\boldsymbol{A}$ 时，$\boldsymbol{x}\mapsto\boldsymbol{A}\boldsymbol{x}$ 是线性映射，微分为 $\boldsymbol{h}\mapsto\boldsymbol{A}\boldsymbol{h}$，扰动是向量；固定 $\boldsymbol{x}$ 时，$\boldsymbol{A}\mapsto\boldsymbol{A}\boldsymbol{x}$ 也是线性映射，微分为 $\boldsymbol{E}\mapsto\boldsymbol{E}\boldsymbol{x}$，扰动是矩阵。两者同时变化时，把 $(\boldsymbol{A},\boldsymbol{x})$ 看作乘积空间 $\mathbb{R}^{m\times n}\times\mathbb{R}^{n}$ 中的一个输入，取乘积范数 $\|(\boldsymbol{E},\boldsymbol{h})\| = (\|\boldsymbol{E}\|_F^2+\|\boldsymbol{h}\|_2^2)^{1/2}$。精确增量

$$(\boldsymbol{A}+\boldsymbol{E})(\boldsymbol{x}+\boldsymbol{h}) - \boldsymbol{A}\boldsymbol{x} = \boldsymbol{A}\boldsymbol{h} + \boldsymbol{E}\boldsymbol{x} + \boldsymbol{E}\boldsymbol{h}$$

中，$\|\boldsymbol{E}\boldsymbol{h}\|_2 \le \|\boldsymbol{E}\|_F\|\boldsymbol{h}\|_2 \le \tfrac{1}{2}\|(\boldsymbol{E},\boldsymbol{h})\|^2$，所以联合微分为 $(\boldsymbol{E},\boldsymbol{h})\mapsto\boldsymbol{A}\boldsymbol{h}+\boldsymbol{E}\boldsymbol{x}$，余项 $\boldsymbol{E}\boldsymbol{h}$ 对联合扰动是二次量。

标量输出与矩阵梯度 输出为标量（$r=s=1$）时，$\mathrm{d}f_{\boldsymbol{X}}$ 是矩阵空间上的线性泛函。矩阵空间取 Frobenius 内积，由 Riesz 表示定理（定理 3.70），这个泛函可以唯一写成与一个同形矩阵的内积，这个矩阵就是梯度。这与向量情形 $\mathrm{d}f_{\boldsymbol{a}}(\boldsymbol{h}) = \nabla f(\boldsymbol{a})^{\top}\boldsymbol{h}$ 完全对应。

定义 18.1　矩阵标量函数的梯度　设 $f:\mathcal{U}\to\mathbb{R}$ 在 $\boldsymbol{X}$ 处可微。唯一满足

$$\mathrm{d}f_{\boldsymbol{X}}(\boldsymbol{H}) = \langle \nabla_{\boldsymbol{X}} f, \boldsymbol{H}\rangle_F = \operatorname{tr}\big((\nabla_{\boldsymbol{X}} f)^{\top}\boldsymbol{H}\big) \tag{18.1}$$

的同形矩阵 $\nabla_{\boldsymbol{X}} f\in\mathbb{R}^{m\times n}$ 称为矩阵梯度。

取只有第 (i,j) 个元素为 1 的扰动 $\boldsymbol{H}$，右侧内积只剩 $\nabla_{\boldsymbol{X}} f$ 的第 (i,j) 个元素，左侧是对 $X_{i,j}$ 的偏导数。所以矩阵梯度的各元素就是对相应矩阵元素的偏导数，唯一性也由此得到。与向量梯度一样，在 Frobenius 长度下，$\nabla_{\boldsymbol{X}} f$ 指出使 f 增加最快的扰动方向。

求梯度的一般做法是：先展开微分，再利用迹的循环移位把扰动移到末端，写成 $\operatorname{tr}(\boldsymbol{G}^{\top}\mathrm{d}\boldsymbol{X})$ 的形式，便读出 $\nabla_{\boldsymbol{X}} f = \boldsymbol{G}$。乘积形状相容时，

$$\operatorname{tr}(\boldsymbol{AB}) = \operatorname{tr}(\boldsymbol{BA})$$

$$\operatorname{tr}(\boldsymbol{ABC}) = \operatorname{tr}(\boldsymbol{BCA}).$$

这里循环移动的是整个因子，不能任意交换相邻矩阵。标量等于自己的迹，所以任何标量表达式都可以放进迹中再移位。

示例 18.2　双线性函数的矩阵梯度　对固定向量 $\boldsymbol{a} \in \mathbb{R}^m$、$\boldsymbol{b} \in \mathbb{R}^n$，令 $f(\boldsymbol{W}) = \boldsymbol{a}^{\top}\boldsymbol{W}\boldsymbol{b}$。它对 $\boldsymbol{W}$ 线性，微分为 $\mathrm{d}f = \boldsymbol{a}^{\top}(\mathrm{d}\boldsymbol{W})\boldsymbol{b}$。把这个标量写成迹并循环移位，

$$\mathrm{d}f = \operatorname{tr}\big(\boldsymbol{a}^{\top}(\mathrm{d}\boldsymbol{W})\boldsymbol{b}\big) = \operatorname{tr}\big(\boldsymbol{b}\boldsymbol{a}^{\top}\mathrm{d}\boldsymbol{W}\big) = \operatorname{tr}\big((\boldsymbol{a}\boldsymbol{b}^{\top})^{\top}\mathrm{d}\boldsymbol{W}\big),$$

于是 $\nabla_{\boldsymbol{W}} f = \boldsymbol{a}\boldsymbol{b}^{\top}$。逐元素核对：$f = \sum_{k,l} a_k W_{k,l} b_l$，对 $W_{i,j}$ 的偏导数是 $a_i b_j$，正是 $\boldsymbol{a}\boldsymbol{b}^{\top}$ 的第 (i,j) 个元素。

结构化变量的梯度　矩阵梯度的唯一性用到了全部矩阵方向。若变量限制在线性子空间 $\mathcal{S}$ 中，例如对称矩阵空间，允许的扰动只能取 $\mathcal{S}$ 中的方向。在 $\mathcal{S}$ 上沿用 Frobenius 内积，Riesz 表示定理在 $\mathcal{S}$ 内给出唯一的表示矩阵，称为受限梯度。设 f 在全矩阵空间中有可微的延拓，环境梯度为 $\boldsymbol{G}$，记 $P_{\mathcal{S}}$ 为到 $\mathcal{S}$ 的正交投影。$\boldsymbol{G} - P_{\mathcal{S}}\boldsymbol{G}$ 与 $\mathcal{S}$ 正交（第 3.5.4节），所以对 $\boldsymbol{H} \in \mathcal{S}$ 有 $\langle \boldsymbol{G}, \boldsymbol{H}\rangle_F = \langle P_{\mathcal{S}}\boldsymbol{G}, \boldsymbol{H}\rangle_F$：受限梯度就是环境梯度的正交投影。

对称矩阵空间中，任一矩阵分解为对称部分与反对称部分，二者 Frobenius 正交，因为对称 $\boldsymbol{S}$ 与反对称 $\boldsymbol{K}$ 满足 $\operatorname{tr}(\boldsymbol{S}\boldsymbol{K}) = \operatorname{tr}((\boldsymbol{S}\boldsymbol{K})^{\top}) = -\operatorname{tr}(\boldsymbol{K}\boldsymbol{S}) = -\operatorname{tr}(\boldsymbol{S}\boldsymbol{K})$；因此投影为 $(\boldsymbol{G}+\boldsymbol{G}^{\top})/2$。若在 $\mathcal{S}$ 中仍使用环境梯度，满足 $\mathrm{d}f(\boldsymbol{H}) = \langle \cdot, \boldsymbol{H}\rangle_F$（$\boldsymbol{H} \in \mathcal{S}$）的矩阵就不唯一：$\boldsymbol{G}$ 加上任一与 $\mathcal{S}$ 正交的矩阵都满足。

对称正定矩阵组成对称矩阵空间中的开集：由第 7章的 Weyl 界，对称扰动的谱范数小于最小特征值时正定性保持。所以讨论正定变量时，邻域和扰动方向都在对称子空间内理解。矩阵输出时没有这样的单个梯度矩阵，只能保留线性映射 $\mathrm{d}\Phi_{\boldsymbol{X}}$ 本身。

18.2　基本矩阵运算的微分

本节从最简单的矩阵运算开始。线性运算的余项为零；乘法与平方的增量可以直接展开，微分之外剩下的部分就是可以精确写出的余项，由它验证可微性；迹、Frobenius 范数平方与二次型则用来练习读出梯度。

线性运算 加法、固定标量的数乘、转置与迹都是线性映射，精确增量就是它们作用于扰动的结果，余项为零，所以微分等于运算本身：

$$\begin{aligned} \mathrm{d}(\boldsymbol{X}+\boldsymbol{Y}) &= \mathrm{d}\boldsymbol{X}+\mathrm{d}\boldsymbol{Y}, \\ \mathrm{d}(c\boldsymbol{X}) &= c\,\mathrm{d}\boldsymbol{X}, \\ \mathrm{d}(\boldsymbol{X}^{\top}) &= (\mathrm{d}\boldsymbol{X})^{\top}, \\ \mathrm{d}\,\mathrm{tr}\,\boldsymbol{X} &= \mathrm{tr}(\mathrm{d}\boldsymbol{X}). \end{aligned}$$

固定矩阵从两侧相乘也是线性的：$\mathrm{d}(\boldsymbol{A}\boldsymbol{X}\boldsymbol{B}) = \boldsymbol{A}(\mathrm{d}\boldsymbol{X})\boldsymbol{B}$，扰动夹在中间的位置不能移动。复合运算沿用第 17.3.2节的链式法则：先计算内部扰动，再让外部微分作用于它。只要逐步核对每个线性映射的输入、输出形状，就不需要另背一套矩阵求导规则。

线性迹函数的微分已经是式 (18.1)的形式，可以直接读出梯度。对固定的 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$，令 $f(\boldsymbol{X}) = \mathrm{tr}(\boldsymbol{A}^{\top}\boldsymbol{X}) = \sum_{i,j} A_{i,j}X_{i,j}$。由于 f 线性，$f(\boldsymbol{X}+\boldsymbol{H}) - f(\boldsymbol{X}) = \mathrm{tr}(\boldsymbol{A}^{\top}\boldsymbol{H})$，没有余项，所以

$$\nabla_{\boldsymbol{X}}\,\mathrm{tr}(\boldsymbol{A}^{\top}\boldsymbol{X}) = \boldsymbol{A}. \tag{18.2}$$

这与向量情形 $\nabla_{\boldsymbol{x}}(\boldsymbol{a}^{\top}\boldsymbol{x}) = \boldsymbol{a}$ 对应，常用于从迹表达式中读出梯度。

乘积的精确增量 两个因子同时变化时，只用分配律就得到

$$(\boldsymbol{A}+\boldsymbol{E})(\boldsymbol{B}+\boldsymbol{H}) - \boldsymbol{A}\boldsymbol{B} = \boldsymbol{A}\boldsymbol{H}+\boldsymbol{E}\boldsymbol{B}+\boldsymbol{E}\boldsymbol{H}. \tag{18.3}$$

这一等式对任意大小的扰动都成立，本身不涉及微分。前两项对 $(\boldsymbol{E},\boldsymbol{H})$ 线性，各被另一个因子放大：在满足乘积不等式的矩阵范数下，$\|\boldsymbol{A}\boldsymbol{H}+\boldsymbol{E}\boldsymbol{B}\| \le \|\boldsymbol{A}\|\|\boldsymbol{H}\| + \|\boldsymbol{E}\|\|\boldsymbol{B}\|$。要把它们识别为微分，还须选定联合输入的大小，例如 $\|(\boldsymbol{E},\boldsymbol{H})\| = (\|\boldsymbol{E}\|_F^2 + \|\boldsymbol{H}\|_F^2)^{1/2}$。由 Frobenius 范数的次乘性，

$$\|\boldsymbol{E}\boldsymbol{H}\|_F \le \|\boldsymbol{E}\|_F\|\boldsymbol{H}\|_F \le \tfrac{1}{2}\|(\boldsymbol{E},\boldsymbol{H})\|^2,$$

交叉项除以联合扰动的大小后趋于零。所以

$$\mathrm{D}(\boldsymbol{A}\boldsymbol{B})[\boldsymbol{E},\boldsymbol{H}] = \boldsymbol{A}\boldsymbol{H}+\boldsymbol{E}\boldsymbol{B},$$

而 $\boldsymbol{E}\boldsymbol{H}$ 是可以直接计算的精确余项。只固定一个因子时，乘积对另一个因子线性，交叉项不出现。

令两因子相同, $\Phi(\boldsymbol{X}) = \boldsymbol{X}^2$ 的精确增量为 $(\boldsymbol{X}+\boldsymbol{E})^2 - \boldsymbol{X}^2 = \boldsymbol{X}\boldsymbol{E} + \boldsymbol{E}\boldsymbol{X} + \boldsymbol{E}^2$。由 $\|\boldsymbol{E}^2\|_F \le \|\boldsymbol{E}\|_F^2$，得到 $\mathrm{d}(\boldsymbol{X}^2)(\boldsymbol{E}) = \boldsymbol{X}\boldsymbol{E} + \boldsymbol{E}\boldsymbol{X}$，余项恰为 $\boldsymbol{E}^2$。只有 $\boldsymbol{X}$ 与扰动交换时，才能写成 $2\boldsymbol{X}\boldsymbol{E}$。例如

$$\boldsymbol{X} = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}, \qquad \boldsymbol{E} = \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix}$$

时，$\boldsymbol{X}\boldsymbol{E} = \mathrm{diag}(1,0)$、$\boldsymbol{E}\boldsymbol{X} = \mathrm{diag}(0,1)$，正确的一阶项是 $\boldsymbol{I}$，而照搬标量规则的 $2\boldsymbol{X}\boldsymbol{E} = \mathrm{diag}(2,0)$ 是错的。直接核对：$(\boldsymbol{X} + t\boldsymbol{E})^2 = t\boldsymbol{I}$，对 t 的导数正是 $\boldsymbol{I}$；本例中 $\boldsymbol{E}^2 = \boldsymbol{0}$，余项为零。

Frobenius 范数平方与二次型　标量值运算的微分可以直接读出梯度。双线性形式 $\boldsymbol{a}^{\top}\boldsymbol{W}\boldsymbol{b}$ 已在示例 18.2中处理。Frobenius 范数平方的精确增量为

$$\|\boldsymbol{X} + \boldsymbol{E}\|_F^2 - \|\boldsymbol{X}\|_F^2 = 2\langle \boldsymbol{X}, \boldsymbol{E} \rangle_F + \|\boldsymbol{E}\|_F^2,$$

所以 $\nabla_{\boldsymbol{X}} \|\boldsymbol{X}\|_F^2 = 2\boldsymbol{X}$，余项恰为 $\|\boldsymbol{E}\|_F^2$。

同一个数组在固定线性作用和可变输入两种角色下，会产生不同的导数, 二次型 $\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x}$ 是典型的例子。固定 $\boldsymbol{A}$、以 $\boldsymbol{x}$ 为变量时, 由式 (17.3), 梯度为 $(\boldsymbol{A}+\boldsymbol{A}^{\top})\boldsymbol{x}$, 是向量; 固定 $\boldsymbol{x}$、以 $\boldsymbol{A}$ 为变量时, $\boldsymbol{x}^{\top}\boldsymbol{E}\boldsymbol{x} = \mathrm{tr}(\boldsymbol{x}\boldsymbol{x}^{\top}\boldsymbol{E}) = \langle \boldsymbol{x}\boldsymbol{x}^{\top}, \boldsymbol{E} \rangle_F$, 梯度为 $\boldsymbol{x}\boldsymbol{x}^{\top}$，是矩阵，且没有余项。两者同时变化时，展开得

$$\begin{aligned} &(\boldsymbol{x}+\boldsymbol{h})^{\top}(\boldsymbol{A}+\boldsymbol{E})(\boldsymbol{x}+\boldsymbol{h}) - \boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x} \\ &\quad = \boldsymbol{x}^{\top}(\boldsymbol{A}+\boldsymbol{A}^{\top})\boldsymbol{h} + \boldsymbol{x}^{\top}\boldsymbol{E}\boldsymbol{x} + \big(\boldsymbol{h}^{\top}\boldsymbol{A}\boldsymbol{h} + \boldsymbol{x}^{\top}\boldsymbol{E}\boldsymbol{h} + \boldsymbol{h}^{\top}\boldsymbol{E}\boldsymbol{x} + \boldsymbol{h}^{\top}\boldsymbol{E}\boldsymbol{h}\big). \end{aligned}$$

括号中的每一项都至少含两个扰动因子，对联合扰动是高阶量，所以联合微分是两个单独微分之和：$(\boldsymbol{E}, \boldsymbol{h}) \mapsto \boldsymbol{x}^{\top}(\boldsymbol{A}+\boldsymbol{A}^{\top})\boldsymbol{h} + \boldsymbol{x}^{\top}\boldsymbol{E}\boldsymbol{x}$。

18.3　求逆的微分

求逆映射 $\mathrm{inv}(\boldsymbol{A}) = \boldsymbol{A}^{-1}$ 定义在 $d \times d$ 可逆矩阵组成的集合上，输入、输出都是方阵，属于矩阵输出的情形，没有单个梯度矩阵，要直接求微分。逆矩阵与行列式非零的关系已在第 1.2.8节及第 1.3.1节建立。本节的矩阵范数取由向量范数诱导的矩阵范数，它使 $\|\boldsymbol{I}\| = 1$ 并满足乘积不等式。

由逆差恒等式得到微分　设 $\boldsymbol{A}$ 可逆，$\boldsymbol{B} = \boldsymbol{A} + \boldsymbol{E}$，并设 $q = \|\boldsymbol{A}^{-1}\|\|\boldsymbol{E}\| < 1$。第 14.1.1节已经证明，这时 $\boldsymbol{B}$ 可逆，逆差满足精确恒等式 (14.1)，即 $\boldsymbol{B}^{-1} - \boldsymbol{A}^{-1} = -\boldsymbol{B}^{-1}\boldsymbol{E}\boldsymbol{A}^{-1}$，并且

$$\|\boldsymbol{B}^{-1} - \boldsymbol{A}^{-1}\| \le \frac{\|\boldsymbol{A}^{-1}\|^2 \|\boldsymbol{E}\|}{1 - q}.$$

特别地，可逆矩阵组成开集，而且 $\boldsymbol{E}\to\boldsymbol{0}$ 时 $\boldsymbol{B}^{-1}\to\boldsymbol{A}^{-1}$，求逆是连续的。

恒等式右端含未知的 $\boldsymbol{B}^{-1}$，还不是对 $\boldsymbol{E}$ 线性的式子。把其中的 $\boldsymbol{B}^{-1}$ 换成 $\boldsymbol{A}^{-1}$，就得到线性的候选项 $-\boldsymbol{A}^{-1}\boldsymbol{E}\boldsymbol{A}^{-1}$。替换造成的差为

$$\boldsymbol{B}^{-1}-\boldsymbol{A}^{-1}+\boldsymbol{A}^{-1}\boldsymbol{E}\boldsymbol{A}^{-1}=-(\boldsymbol{B}^{-1}-\boldsymbol{A}^{-1})\boldsymbol{E}\boldsymbol{A}^{-1},$$

其范数不超过 $\|\boldsymbol{B}^{-1}-\boldsymbol{A}^{-1}\|\,\|\boldsymbol{E}\|\,\|\boldsymbol{A}^{-1}\|$。由上面的连续性，第一个因子随 $\boldsymbol{E}\to\boldsymbol{0}$ 趋于零，所以这个差是 $o(\|\boldsymbol{E}\|)$。有限维矩阵空间中各种范数等价，对 Frobenius 范数同样如此。因此求逆在每个可逆矩阵处可微，且

$$\mathrm{d}(\boldsymbol{X}^{-1})=-\boldsymbol{X}^{-1}(\mathrm{d}\boldsymbol{X})\boldsymbol{X}^{-1}. \tag{18.4}$$

这个导数以矩阵方向 $\mathrm{d}\boldsymbol{X}$ 为输入，输出仍是同形的方阵；它是矩阵空间上的线性映射，不能写成单个梯度矩阵。上面的差还可以精确写出并给出二次界，这在第 20.2.2节用于估计一阶预测的误差。

这里先由精确恒等式确认了可微性。随后可以对恒等式 $\boldsymbol{X}\boldsymbol{X}^{-1}=\boldsymbol{I}$ 两侧求微分作交叉核对：左侧用乘积法则，右侧是常矩阵，得到 $(\mathrm{d}\boldsymbol{X})\boldsymbol{X}^{-1}+\boldsymbol{X}\,\mathrm{d}(\boldsymbol{X}^{-1})=\boldsymbol{0}$，左乘 $\boldsymbol{X}^{-1}$ 便回到同一公式。这一形式推导以逆映射可微为前提，不能单独承担可微性的证明。

1×1 时这就是 $(1/x)'=-1/x^2$。两个 $\boldsymbol{X}^{-1}$ 位于扰动两侧，不能合并成 $-\boldsymbol{X}^{-2}\mathrm{d}\boldsymbol{X}$，因为 $\mathrm{d}\boldsymbol{X}$ 未必与 $\boldsymbol{X}^{-1}$ 交换。取一个对角矩阵和一个非对角扰动，就能看出两种写法的差别。

示例 18.3　逆矩阵微分中的乘法次序　取 $\boldsymbol{X}=\mathrm{diag}(2,1)$，扰动方向

$$\boldsymbol{E}=\begin{bmatrix}0&1\\1&0\end{bmatrix}.$$

由式 (18.4)，沿 $\boldsymbol{X}+t\boldsymbol{E}$ 求逆矩阵在 $t=0$ 处的导数为

$$-\boldsymbol{X}^{-1}\boldsymbol{E}\boldsymbol{X}^{-1}=\begin{bmatrix}0&-1/2\\-1/2&0\end{bmatrix}.$$

若照搬标量规则而写成 $-\boldsymbol{X}^{-2}\boldsymbol{E}$，会得到

$$\begin{bmatrix}0&-1/4\\-1&0\end{bmatrix}.$$

两种写法给出不同的矩阵。要判断哪一个正确，可以直接写出这条路径上的逆矩阵：

$$(\boldsymbol{X}+t\boldsymbol{E})^{-1}=\frac{1}{2-t^2}\begin{bmatrix}1 & -t\\ -t & 2\end{bmatrix}.$$

在 $t=0$ 处对 t 求导，两个非对角元的导数都是 $-1/2$，对角元的导数为 0，与第一种结果一致。

错误写法连对称性都丢失了。路径 $\boldsymbol{X}+t\boldsymbol{E}$ 在 $t=0$ 附近由对称可逆矩阵组成，它们的逆也对称，所以导数必须对称。这种结构检查能直接发现错误。

矩阵沿可微的参数曲线 $\boldsymbol{A}(t)$ 变化，且每个 $\boldsymbol{A}(t)$ 可逆时，链式法则与式 (18.4)给出

$$\frac{\mathrm{d}}{\mathrm{d}t}\boldsymbol{A}(t)^{-1}=-\boldsymbol{A}(t)^{-1}\boldsymbol{A}'(t)\boldsymbol{A}(t)^{-1}.$$

第 18.5节和第 20章沿扰动线段求导时都会用到这个公式。

18.4　行列式的微分

行列式把方阵映为一个实数，它的绝对值是线性映射对体积的缩放倍数（第 1.3.1节）。按排列展开，$\det\boldsymbol{A}$ 是各元素的多项式，所以它在全部方阵上连续可微，奇异矩阵处也不例外。本节由逐列展开算出微分，再在可逆时化为迹的形式。

代数余子式形式　行列式对每一列分别线性（第 1.3.1节）。记 $\boldsymbol{A}\in\mathbb{R}^{d\times d}$ 的列为 $\boldsymbol{a}_1,\dots,\boldsymbol{a}_d$，扰动 $\boldsymbol{E}$ 的列为 $\boldsymbol{e}_1,\dots,\boldsymbol{e}_d$，逐列展开 $\det(\boldsymbol{a}_1+\boldsymbol{e}_1,\dots,\boldsymbol{a}_d+\boldsymbol{e}_d)$，得到 2^d 项，每一项在每一列取 $\boldsymbol{a}_j$ 或 $\boldsymbol{e}_j$。全取 $\boldsymbol{a}_j$ 的一项是 $\det\boldsymbol{A}$；恰有第 j 列取 $\boldsymbol{e}_j$ 的一项，按第 j 列展开（第 1.3.1.4节）等于 $\sum_i E_{i,j}C_{i,j}$，其中 $C_{i,j}$ 是 $\boldsymbol{A}$ 的代数余子式，它不依赖 $\boldsymbol{A}$ 的第 j 列。其余各项至少含两列扰动，是 $\boldsymbol{E}$ 的元素的多项式，且每个单项至少二次；由 $|E_{i,j}|\le\|\boldsymbol{E}\|_F$，在 $\|\boldsymbol{E}\|_F\le 1$ 时它们的和不超过某个常数乘 $\|\boldsymbol{E}\|_F^2$。于是

$$\mathrm{d}\det_{\boldsymbol{A}}(\boldsymbol{E})=\sum_{i,j}C_{i,j}E_{i,j}=\langle\boldsymbol{C},\boldsymbol{E}\rangle_F=\operatorname{tr}\bigl(\operatorname{adj}(\boldsymbol{A})\boldsymbol{E}\bigr),\tag{18.5}$$

其中 $\boldsymbol{C}=[C_{i,j}]$ 是代数余子式矩阵，$\operatorname{adj}(\boldsymbol{A})=\boldsymbol{C}^{\top}$ 是古典伴随。Frobenius 梯度为 $\nabla_{\boldsymbol{A}}\det=\boldsymbol{C}$。这个公式在奇异矩阵处同样成立。

$\boldsymbol{A}$ 可逆时，古典伴随恒等式（定理 1.31）给出 $\operatorname{adj}(\boldsymbol{A}) = \det(\boldsymbol{A})\boldsymbol{A}^{-1}$，代入得到 Jacobi 公式的一阶形式

$$\mathrm{d}\det \boldsymbol{X} = \det(\boldsymbol{X})\operatorname{tr}(\boldsymbol{X}^{-1}\mathrm{d}\boldsymbol{X}),$$

相应的梯度为 $\det(\boldsymbol{X})\boldsymbol{X}^{-\mathsf{T}}$。它说明有向体积缩放倍数的相对变化为

$$\frac{\mathrm{d}\det \boldsymbol{X}}{\det \boldsymbol{X}} = \operatorname{tr}(\boldsymbol{X}^{-1}\mathrm{d}\boldsymbol{X}).$$

也可以用乘法公式核对：

$$\det(\boldsymbol{X}+\boldsymbol{H}) = \det(\boldsymbol{X})\det(\boldsymbol{I}+\boldsymbol{X}^{-1}\boldsymbol{H}),$$

问题化归为单位矩阵附近的一阶变化。奇异处没有 $\boldsymbol{X}^{-1}$，只能使用代数余子式或古典伴随的形式。

在最简单的基点 $\boldsymbol{I}$ 处，代数余子式矩阵就是 $\boldsymbol{I}$，一阶变化是扰动的迹。

示例 18.4　单位矩阵附近行列式的一阶变化　取 $\boldsymbol{H} = \operatorname{diag}(\varepsilon_1, \varepsilon_2)$，则

$$\det(\boldsymbol{I}+\boldsymbol{H}) = (1+\varepsilon_1)(1+\varepsilon_2) = 1 + \varepsilon_1 + \varepsilon_2 + \varepsilon_1\varepsilon_2,$$

一阶变化是 $\varepsilon_1 + \varepsilon_2 = \operatorname{tr}\boldsymbol{H}$。若扰动只在非对角位置，例如

$$\boldsymbol{H} = \begin{bmatrix} 0 & \varepsilon \\ 0 & 0 \end{bmatrix},$$

则 $\det(\boldsymbol{I}+\boldsymbol{H}) = 1$，面积不变，而 $\operatorname{tr}\boldsymbol{H} = 0$。

两个方向各拉长一点时，面积的相对增量一阶上是两个伸长率之和；剪切扰动不改变面积，迹也为零。两种情形中，一阶变化都等于扰动的迹。

18.5 对数行列式的微分

实值的 $\log\det \boldsymbol{A}$ 要求 $\det \boldsymbol{A} > 0$。行列式连续，满足这一条件的方阵组成开集，对数在其上与行列式复合。对行列式的微分应用标量对数的链式法则 $\mathrm{d}\log u = \mathrm{d}u/u$，得到

$$\begin{aligned} \mathrm{d}\log\det \boldsymbol{X} &= \operatorname{tr}(\boldsymbol{X}^{-1}\mathrm{d}\boldsymbol{X}) \\ \nabla_{\boldsymbol{X}}\log\det \boldsymbol{X} &= \boldsymbol{X}^{-\mathsf{T}}. \end{aligned} \tag{18.6}$$

第二式由 $\operatorname{tr}(\boldsymbol{X}^{-1}\mathrm{d}\boldsymbol{X}) = \operatorname{tr}\big((\boldsymbol{X}^{-\mathsf{T}})^{\mathsf{T}}\mathrm{d}\boldsymbol{X}\big)$ 对照式 (18.1)读出。若 $\boldsymbol{X}$ 还对称，则 $\boldsymbol{X}^{-\mathsf{T}} = \boldsymbol{X}^{-1}$；一般情形应保留转置。$1\times 1$ 时它回到 $(\log x)' = 1/x$。

对称正定变量　统计与优化中常见的是对称正定矩阵上的 $\log\det$。这时变量在对称矩阵子空间中，只允许对称扰动。由第 18.1节，受限梯度是环境梯度 $\boldsymbol{A}^{-\mathsf{T}} = \boldsymbol{A}^{-1}$ 在对称子空间上的投影；它本身已对称，所以梯度就是 $\boldsymbol{A}^{-1}$。

这里有两个不同的定义域。$\det > 0$ 的方阵组成全矩阵空间中的开集，$\log\det$ 在其上已有定义，式 (18.6)在这个开集上处处成立；对称正定矩阵组成对称子空间中的开集，是前者与对称子空间之交的一部分。所以正定性不是 $\log\det$ 可微的条件，它只决定允许的扰动方向和梯度的表示。第 20.2.4节估计有限扰动下的余项时，正定性还提供整条扰动线段留在定义域内的明确保证。

18.6　本章小结

以矩阵为自变量时，微分仍是全部同形扰动上的线性映射，只是保留了矩阵形状。标量输出时，Riesz 表示在 Frobenius 内积下给出同形的梯度矩阵，常用的读法是把微分写成 $\operatorname{tr}(\boldsymbol{G}^{\mathsf{T}}\mathrm{d}\boldsymbol{X})$；矩阵输出时没有单个梯度矩阵，只能保留微分本身，例如求逆的 $\mathrm{d}\boldsymbol{X} \mapsto -\boldsymbol{X}^{-1}\mathrm{d}\boldsymbol{X}\boldsymbol{X}^{-1}$。变量限制在对称矩阵等子空间时，允许的方向随之受限，受限梯度是环境梯度的正交投影，对称情形为 $(\boldsymbol{G}+\boldsymbol{G}^{\mathsf{T}})/2$。

各运算的公式与条件可以这样归纳。线性运算的微分就是运算本身；乘积的微分是两个“只变一个因子”的项之和，因子顺序不能交换，平方的微分是 $\boldsymbol{X}\mathrm{d}\boldsymbol{X} + \mathrm{d}\boldsymbol{X}\boldsymbol{X}$ 而不是 $2\boldsymbol{X}\mathrm{d}\boldsymbol{X}$。求逆在可逆矩阵的开集上可微，扰动夹在两个逆矩阵之间。行列式是多项式，在包括奇异矩阵的全部方阵上可微，微分由代数余子式给出，可逆时化为 $\det(\boldsymbol{X})\operatorname{tr}(\boldsymbol{X}^{-1}\mathrm{d}\boldsymbol{X})$。对数行列式在 $\det > 0$ 的开集上可微，梯度为 $\boldsymbol{X}^{-\mathsf{T}}$，对称正定情形化为 $\boldsymbol{X}^{-1}$。

所有公式都先由增量的一阶项识别、再由余项验证可微，对 $\boldsymbol{X}\boldsymbol{X}^{-1} = \boldsymbol{I}$ 等恒等式形式求导只能作核对。精确增量中的余项本章只用来证明可微；这些公式作为一阶工具，在第 20章用来估计条件数和有限扰动下一阶预测的误差。

第 19 章

隐函数与反函数

前面各章对给定的显式映射求微分。本章反过来从方程出发：给定一组方程，判断它能否在基点附近确定唯一的函数，并求这个函数的导数。

实际问题中，变量之间常由约束联系，而不是由显式公式给出。单位圆上的点满足 $x^2+y^2=1$，物理系统的平衡状态满足力的平衡方程，训练得到的最优参数满足梯度为零。我们关心的是：一部分变量（参数）稍作改变时，其余变量（未知量）是否随之唯一地、光滑地改变，变化率又是多少。

方程组用向量值映射表示。方程个数与待解变量个数相同时，关于待解变量的方阵 Jacobian 是否可逆，决定了能否在局部解出这些变量。第一节建立隐函数定理：先用例子说明为什么必须指定起始解、为什么条件落在待解变量的导数上，再用压缩迭代证明局部解的存在、唯一与可微，最后给出导数公式。第二节把输出当作参数、输入当作待解变量，由隐函数定理得到局部反函数定理，并说明局部可逆不能推出整体单射。

证明要用到第 17章的链式法则、向量值中值估计与压缩的概念，以及第 3章有限维空间的完备性。本章只回答解是否存在、是否唯一、怎样求导。隐式给定的特征值与特征向量分支对矩阵扰动的响应有多大，在第 20章用这里的定理分析。

19.1 隐函数的存在与微分

显式函数直接给出输出，例如 $y=\sqrt{x}$。关系 $F(x,y)=0$ 则没有直接说明给定 x 时 y 取什么值：满足方程的 y 可能有多个，也可能一个都没有。

设 (a,b) 满足 $F(a,b)=0$。若存在 a 附近的区间 I、b 附近的区间 J 和函数 $\varphi: I\to J$，使得对 $I\times J$ 中的点，$F(x,y)=0$ 成立恰好当 $y=\varphi(x)$，就称方程在 (a,b) 附近确定了一个**隐函数**（implicit function）$y=\varphi(x)$。换句话说，只看 (a,b) 附近的小矩形，方程的解集恰是一个函数的图像。因此先要说明局部解分支存在且唯一，然后才能对这条分支求导。

同一个方程在一些点附近确定隐函数，在另一些点附近则不确定。

示例 19.1　单位圆附近的隐函数　考虑单位圆 $x^2+y^2-1=0$。在 $(0,1)$ 附近，解集是上半圆 $y=\sqrt{1-x^2}$ 的一段；在 $(0,-1)$ 附近则是下半圆 $y=-\sqrt{1-x^2}$ 的一段，两处都确定了隐函数。但在 $(1,0)$ 附近，每个略小于 1 的 x 对应上下两个解，略大于 1 的 x 没有解；无论矩形多小，解集都不是关于 x 的函数图像。此处圆的切线是竖直的。

解集分成几支时，还要指定从哪一个解出发。

示例 19.2　方程 $y^2=x$ 的两支解　方程 $y^2-x=0$ 在 $x>0$ 时有正、负两支解 $y=\pm\sqrt{x}$。固定其中一个非零解，例如 $(1,1)$，可以在它附近选出唯一的正支。但在 $(0,0)$ 处两支相交，负 x 侧又没有实数解，因此不存在定义在含 0 的开区间上的解函数。

两个例子中不能局部解出 y 的点，都满足 $\partial F/\partial y=2y=0$：单位圆在 $(1,0)$ 处如此，y^2-x 在 $(0,0)$ 处也如此。下面的定理 19.3要求的可逆性，恰好在这些点失效。所以局部选解既要指定起始解，也要核对关于待解变量的导数。换一个被解变量，非退化条件也随之改变：单位圆在 $(1,0)$ 处虽不能把 y 解成 x 的函数，却有 $\partial F/\partial x=2\neq 0$，可以在附近把 x 解成 y 的函数 $x=\sqrt{1-y^2}$。

图 19.1显示“局部唯一”怎样排除另一支解。在 $(1,1)$ 附近只保留正支即可；在原点处，两支相交且负 x 没有实数解，不能这样局部选出可微的解。

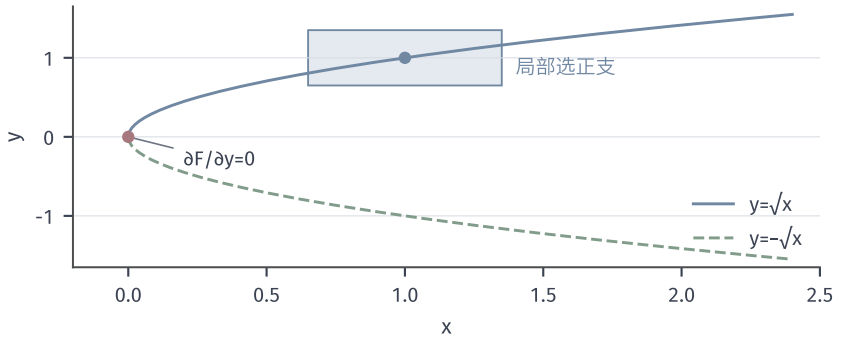


图 19.1　方程 $F(x,y)=y^2-x=0$ 的两支实数解。浅蓝矩形围住 $(1,1)$，在该矩形内每个允许的 x 只有正支解，且 $F_y=2y\neq 0$；红点处 $F_y=0$，两支相交。两支解满足同一方程，选定起始解与邻域才确定隐函数分支。

存在、唯一性与微分　条件之所以落在关于待解变量的导数上，可以从线性方程看出来。

设 $\boldsymbol{x}\in\mathbb{R}^p$ 为参数、$\boldsymbol{y}\in\mathbb{R}^m$ 为未知量，$\boldsymbol{P}\in\mathbb{R}^{m\times p}$、$\boldsymbol{Q}\in\mathbb{R}^{m\times m}$ 固定，方程 $\boldsymbol{P}\boldsymbol{x}+\boldsymbol{Q}\boldsymbol{y}=\boldsymbol{0}$ 有 m 个方程、m 个未知量。当 $\boldsymbol{Q}$ 可逆时，对每个 $\boldsymbol{x}$ 都有唯一解 $\boldsymbol{y}=-\boldsymbol{Q}^{-1}\boldsymbol{P}\boldsymbol{x}$；$\boldsymbol{Q}$ 不可逆时，对给定的 $\boldsymbol{x}$，解要么不存在，要么不唯一。

对非线性方程 $F(\boldsymbol{x},\boldsymbol{y})=\boldsymbol{0}$，可微性说明它在基点附近近似于线性方程

$$\boldsymbol{D}_{\boldsymbol{x}}F(\boldsymbol{a},\boldsymbol{b})(\boldsymbol{x}-\boldsymbol{a})+\boldsymbol{D}_{\boldsymbol{y}}F(\boldsymbol{a},\boldsymbol{b})(\boldsymbol{y}-\boldsymbol{b})\approx\boldsymbol{0},$$

其中 $\boldsymbol{D}_{\boldsymbol{x}}F$、$\boldsymbol{D}_{\boldsymbol{y}}F$ 分别是只对 $\boldsymbol{x}$、只对 $\boldsymbol{y}$ 的坐标求偏导排成的 Jacobian 块。隐函数定理断言：只要线性近似中 $\boldsymbol{Q}=\boldsymbol{D}_{\boldsymbol{y}}F$ 可逆，非线性方程在局部也像线性方程一样有唯一解，而且解的导数就是线性解的系数 $-\boldsymbol{Q}^{-1}\boldsymbol{P}$。

定理给出的是充分条件。它只要求待解变量对应的方阵 Jacobian 可逆，不要求整个带参数映射的 Jacobian 是方阵。

定理 19.3　隐函数定理　设 $F:\mathbb{R}^p\times\mathbb{R}^m\to\mathbb{R}^m$ 在 $(\boldsymbol{a},\boldsymbol{b})$ 的某个开邻域内连续可微，$F(\boldsymbol{a},\boldsymbol{b})=\boldsymbol{0}$，并且关于待解变量的 Jacobian 矩阵

$$\boldsymbol{D}_{\boldsymbol{y}}F(\boldsymbol{a},\boldsymbol{b})\in\mathbb{R}^{m\times m}$$

可逆。则存在 $\boldsymbol{a}$ 与 $\boldsymbol{b}$ 的邻域 U,V，以及唯一的连续可微函数 $\varphi:U\to V$，使 $\varphi(\boldsymbol{a})=\boldsymbol{b}$，并且对所有 $(\boldsymbol{x},\boldsymbol{y})\in U\times V$ 都有

$$F(\boldsymbol{x},\boldsymbol{y})=\boldsymbol{0}\quad\Longleftrightarrow\quad\boldsymbol{y}=\varphi(\boldsymbol{x}).$$

其 Jacobian 矩阵满足

$$\begin{aligned}\boldsymbol{D}\varphi(\boldsymbol{x})=\;&-\bigl[\boldsymbol{D}_{\boldsymbol{y}}F(\boldsymbol{x},\varphi(\boldsymbol{x}))\bigr]^{-1}\\&\cdot\boldsymbol{D}_{\boldsymbol{x}}F(\boldsymbol{x},\varphi(\boldsymbol{x})).\end{aligned}\tag{19.1}$$

矩阵形状为 $(m\times m)(m\times p)=m\times p$，与 $\varphi:\mathbb{R}^p\to\mathbb{R}^m$ 的 Jacobian 一致。唯一性只限于所选的邻域 $U\times V$：定理不排除远处还有满足同一方程的其他解支，例如 $y^2=x$ 在 $(1,1)$ 附近选出正支，负支仍然存在。

若已知 φ 存在且可微，导数公式可以直接由链式法则得到：对恒等式 $F(\boldsymbol{x},\varphi(\boldsymbol{x}))=\boldsymbol{0}$ 求导，得 $\boldsymbol{D}_{\boldsymbol{x}}F+\boldsymbol{D}_{\boldsymbol{y}}F\,\boldsymbol{D}\varphi=\boldsymbol{0}$，再左乘 $(\boldsymbol{D}_{\boldsymbol{y}}F)^{-1}$。定理真正困难的部分是 φ 的存在、唯一与可微，形式求导不能替代这些步骤。

证明的思路是把解方程改写为反复修正的迭代。一元时，固定 x，从 $y_0=b$ 出发，用 $y_{n+1}=y_n-F(x,y_n)/F_y(a,b)$ 不断修正：若 $F(x,y_n)>0$ 且 $F_y(a,b)>0$，就把 y 调小一点。这类似 Newton 法，只是斜率固定用基点处的值。若每次修正都使误差按固定比例缩小，迭代就收敛到唯一解。

证明依次检查三件事：修正映射是压缩；它不把点送出所考察的球；所得解随参数可微。

证明　先把方程改写为局部压缩迭代。记

$$\boldsymbol{A} = \boldsymbol{D}_{\boldsymbol{y}} F(\boldsymbol{a}, \boldsymbol{b})$$
$$T_{\boldsymbol{x}}(\boldsymbol{y}) = \boldsymbol{y} - \boldsymbol{A}^{-1} F(\boldsymbol{x}, \boldsymbol{y}).$$

因为 $\boldsymbol{A}^{-1}$ 可逆，$F(\boldsymbol{x}, \boldsymbol{y}) = \boldsymbol{0}$ 当且仅当 $T_{\boldsymbol{x}}(\boldsymbol{y}) = \boldsymbol{y}$，即 $\boldsymbol{y}$ 是更新后保持不变的点，称为不动点。并且

$$\boldsymbol{D}_{\boldsymbol{y}} T_{\boldsymbol{x}}(\boldsymbol{y}) = \boldsymbol{I} - \boldsymbol{A}^{-1} \boldsymbol{D}_{\boldsymbol{y}} F(\boldsymbol{x}, \boldsymbol{y}),$$

它在 $(\boldsymbol{a}, \boldsymbol{b})$ 处为零。由 F 的导数连续，这个矩阵的元素在基点附近都很小；又谱范数不超过 Frobenius 范数（第 3.3.4节）。因而可以选择闭球 $B = \{\boldsymbol{y} : \|\boldsymbol{y} - \boldsymbol{b}\|_2 \le r\}$ 和 $\boldsymbol{a}$ 的邻域 U，使

$$\sup_{\boldsymbol{x} \in U,\, \boldsymbol{y} \in B} \left\| \boldsymbol{D}_{\boldsymbol{y}} T_{\boldsymbol{x}}(\boldsymbol{y}) \right\|_2 \le q < 1. \tag{19.2}$$

沿 $\boldsymbol{y}$ 方向使用式 (17.10)（球是凸集，球内线段不离开球）可知，每个 $T_{\boldsymbol{x}}$ 都把 B 内任意两点之间的距离缩小到原来的至多 q 倍。

还必须核对自映射，即 $T_{\boldsymbol{x}}$ 不把 B 中的点送出 B；否则迭代可能离开压缩成立的范围。因为 $T_{\boldsymbol{a}}(\boldsymbol{b}) = \boldsymbol{b}$ 且 $T_{\boldsymbol{x}}(\boldsymbol{b})$ 关于 $\boldsymbol{x}$ 连续，可进一步缩小 U，使

$$\|T_{\boldsymbol{x}}(\boldsymbol{b}) - \boldsymbol{b}\|_2 \le \frac{1-q}{2} r.$$

于是对 $\boldsymbol{y} \in B$，先用三角不等式拆开，再用压缩性，

$$\begin{aligned} \|T_{\boldsymbol{x}}(\boldsymbol{y}) - \boldsymbol{b}\|_2 &\le \|T_{\boldsymbol{x}}(\boldsymbol{y}) - T_{\boldsymbol{x}}(\boldsymbol{b})\|_2 + \|T_{\boldsymbol{x}}(\boldsymbol{b}) - \boldsymbol{b}\|_2 \\ &\le q\|\boldsymbol{y} - \boldsymbol{b}\|_2 + \frac{1-q}{2} r \le \frac{1+q}{2} r < r. \end{aligned}$$

所以 $T_{\boldsymbol{x}}(B)$ 包含在 B 的内部 V 中。固定 $\boldsymbol{x} \in U$，从 $\boldsymbol{y}_0 = \boldsymbol{b}$ 出发，令 $\boldsymbol{y}_{n+1} = T_{\boldsymbol{x}}(\boldsymbol{y}_n)$。所有迭代项都留在 B 内，每一步的压缩使相邻差满足 $\|\boldsymbol{y}_{n+1} - \boldsymbol{y}_n\|_2 \le q\|\boldsymbol{y}_n - \boldsymbol{y}_{n-1}\|_2 \le \cdots \le q^n \|\boldsymbol{y}_1 - \boldsymbol{y}_0\|_2$。增大 q 仍保留这个上界，因而可设 $0 < q < 1$。对 $m' > n$，几何和给出

$$\|\boldsymbol{y}_{m'} - \boldsymbol{y}_n\|_2 \le \sum_{j=n}^{m'-1} \|\boldsymbol{y}_{j+1} - \boldsymbol{y}_j\|_2 \le \frac{q^n}{1-q} \|\boldsymbol{y}_1 - \boldsymbol{y}_0\|_2 \longrightarrow 0,$$

所以 $(\boldsymbol{y}_n)$ 是 Cauchy 列。有限维赋范空间完备（定理 3.28），该序列收敛；闭性使极限仍在 B 内。$T_{\boldsymbol{x}}$ 连续，在 $\boldsymbol{y}_{n+1} = T_{\boldsymbol{x}}(\boldsymbol{y}_n)$ 中令 $n \to \infty$，可得极限 $\varphi(\boldsymbol{x})$ 满足 $T_{\boldsymbol{x}}(\varphi(\boldsymbol{x})) = \varphi(\boldsymbol{x})$，而 $T_{\boldsymbol{x}}(B) \subset V$ 使它属于 V。若另

有不动点 $\boldsymbol{z}\in B$，则 $\|\boldsymbol{z}-\varphi(\boldsymbol{x})\|_2=\|T_{\boldsymbol{x}}(\boldsymbol{z})-T_{\boldsymbol{x}}(\varphi(\boldsymbol{x}))\|_2\le q\|\boldsymbol{z}-\varphi(\boldsymbol{x})\|_2$，由 $q<1$ 只能有 $\boldsymbol{z}=\varphi(\boldsymbol{x})$，所以这个不动点唯一。若 $(\boldsymbol{x},\boldsymbol{y})\in U\times V$ 且 $F(\boldsymbol{x},\boldsymbol{y})=\boldsymbol{0}$，则 $\boldsymbol{y}\in B$ 也是 $T_{\boldsymbol{x}}$ 的不动点，唯一性迫使 $\boldsymbol{y}=\varphi(\boldsymbol{x})$。这证明了定理所述的局部存在与零点集合的逐点唯一性。

还需说明所得解随参数连续可微。先证 φ 局部 Lipschitz 连续，即它不会随参数剧烈变化。把 U 进一步缩小为开球，并使 $\overline{U}\times B$ 包含在原定义域内；这个集合闭且有界，$T_{\boldsymbol{x}}(\boldsymbol{y})$ 关于 $\boldsymbol{x}$ 的导数 $-\boldsymbol{A}^{-1}\boldsymbol{D}_{\boldsymbol{x}}F$ 各分量连续，故有统一范数上界 L。对 $\boldsymbol{x},\boldsymbol{x}'\in U$，两点间的线段仍在 U 内，式 (17.10) 可用于 $T_{\boldsymbol{x}}(\boldsymbol{y})$ 的参数变化。利用两个不动点关系 $\varphi(\boldsymbol{x})=T_{\boldsymbol{x}}(\varphi(\boldsymbol{x}))$、$\varphi(\boldsymbol{x}')=T_{\boldsymbol{x}'}(\varphi(\boldsymbol{x}'))$，把差拆成“改变 $\boldsymbol{y}$”与“改变 $\boldsymbol{x}$”两步：

$$\begin{aligned}\|\varphi(\boldsymbol{x})-\varphi(\boldsymbol{x}')\|_2&\le\|T_{\boldsymbol{x}}(\varphi(\boldsymbol{x}))-T_{\boldsymbol{x}}(\varphi(\boldsymbol{x}'))\|_2\\&\quad+\|T_{\boldsymbol{x}}(\varphi(\boldsymbol{x}'))-T_{\boldsymbol{x}'}(\varphi(\boldsymbol{x}'))\|_2\\&\le q\|\varphi(\boldsymbol{x})-\varphi(\boldsymbol{x}')\|_2+L\|\boldsymbol{x}-\boldsymbol{x}'\|_2,\end{aligned}$$

移项得到 $\|\varphi(\boldsymbol{x})-\varphi(\boldsymbol{x}')\|_2\le L\|\boldsymbol{x}-\boldsymbol{x}'\|_2/(1-q)$，故 φ 局部 Lipschitz 连续。

再证可微。令 $\boldsymbol{h}\to\boldsymbol{0}$ 并记 $\boldsymbol{k}=\varphi(\boldsymbol{x}+\boldsymbol{h})-\varphi(\boldsymbol{x})$，前述界给出 $\|\boldsymbol{k}\|_2=O(\|\boldsymbol{h}\|_2)$。两点都在解集上，所以

$$F(\boldsymbol{x}+\boldsymbol{h},\varphi(\boldsymbol{x})+\boldsymbol{k})-F(\boldsymbol{x},\varphi(\boldsymbol{x}))=\boldsymbol{0}.$$

对左侧作联合扰动 $(\boldsymbol{h},\boldsymbol{k})$ 的一阶展开，得到

$$\boldsymbol{D}_{\boldsymbol{x}}F\,\boldsymbol{h}+\boldsymbol{D}_{\boldsymbol{y}}F\,\boldsymbol{k}+o(\|\boldsymbol{h}\|_2)=\boldsymbol{0}.$$

展开中的 Jacobian 均在 $(\boldsymbol{x},\varphi(\boldsymbol{x}))$ 处取值，联合扰动的余项 $o(\|(\boldsymbol{h},\boldsymbol{k})\|_2)$ 因 $\|\boldsymbol{k}\|_2=O(\|\boldsymbol{h}\|_2)$ 成为 $o(\|\boldsymbol{h}\|_2)$。基点的 $\det\boldsymbol{A}\neq0$，行列式又是矩阵元素的连续函数，所以邻域足够小时 $\boldsymbol{D}_{\boldsymbol{y}}F$ 仍可逆。左乘它的逆，得到

$$\boldsymbol{k}=-(\boldsymbol{D}_{\boldsymbol{y}}F)^{-1}\boldsymbol{D}_{\boldsymbol{x}}F\,\boldsymbol{h}+o(\|\boldsymbol{h}\|_2).$$

这证明 φ 可微并给出式 (19.1)；右侧各 Jacobian 矩阵及矩阵求逆都连续，又保证 $\boldsymbol{D}\varphi$ 连续。至此，隐函数定理中的存在、局部唯一与导数公式都已得到证明。 ■

隐函数的导数 定理成立后，计算隐函数的导数只需在选定分支上代入两个 Jacobian。下面回到示例 19.2和示例 19.1的方程，核对不同分支各自的变化率。

示例 19.4　隐函数分支的导数　设 $F(x,y)=y^2-x$，在 $(1,1)$ 处有 $F=0$、$F_y=2\neq 0$。隐函数定理保证 $(1,1)$ 附近的解可以唯一写成 $y=\varphi(x)$，且

$$\varphi'(x)=-\frac{F_x(x,\varphi(x))}{F_y(x,\varphi(x))}=\frac{1}{2\varphi(x)}$$

$$\varphi'(1)=\frac{1}{2}.$$

直接选正支 $\varphi(x)=\sqrt{x}$，求导同样得到 $1/(2\sqrt{x})$。若在 $(1,-1)$ 附近选负支，导数则为 $-1/2$。

对单位圆 $x^2+y^2=1$ 上半圆的一点 (x_0,y_0)（$y_0>0$），同一公式给出 $\varphi'(x_0)=-x_0/y_0$，不必先解出 $y=\sqrt{1-x^2}$。

起始解不同，所追踪的函数也不同，所以导数公式要在选定分支上取值。单位圆的导数 $-x_0/y_0$ 在 $y_0\to 0$ 时趋于无穷，这与 $(1,0)$ 处的竖直切线相符，也与示例 19.1 的结论一致：$(1,0)$ 附近不能把 y 解成 x 的函数。曲线 $y=\varphi(x)$ 的切向量是 $(1,\varphi'(x_0))^{\mathsf T}=(1,-x_0/y_0)^{\mathsf T}$，它与梯度 $\nabla F=(2x_0,2y_0)^{\mathsf T}$ 正交，回应了第 17.2.4 节梯度与等值曲线的关系；梯度非零正是隐函数定理所需的非退化条件。若 Jacobian 奇异，定理不能直接使用：这既不能断言不存在可微分支，也不能默认分支仍唯一而光滑，须另行分析。

与线性解映射的一致性　隐函数公式也可以在有显式解的方程上核对。线性方程 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 在 $\boldsymbol{A}$ 可逆时有解 $\boldsymbol{x}=\boldsymbol{A}^{-1}\boldsymbol{b}$。把 $(\boldsymbol{A},\boldsymbol{b})$ 拉直后看作参数、$\boldsymbol{x}$ 看作未知量，令 $F(\boldsymbol{A},\boldsymbol{b},\boldsymbol{x})=\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}$。关于未知量的 Jacobian 是 $\boldsymbol{A}$，可逆时满足定理条件；关于参数的微分作用于矩阵与右端的扰动 $(\boldsymbol{E},\boldsymbol{f})$，给出 $\boldsymbol{E}\boldsymbol{x}-\boldsymbol{f}$。由式 (19.1)，解分支的微分为

$$(\boldsymbol{E},\boldsymbol{f})\mapsto -\boldsymbol{A}^{-1}(\boldsymbol{E}\boldsymbol{x}-\boldsymbol{f})=\boldsymbol{A}^{-1}(\boldsymbol{f}-\boldsymbol{E}\boldsymbol{x}).$$

直接对显式解 $\boldsymbol{A}^{-1}\boldsymbol{b}$ 用乘积法则与求逆的微分 (18.4)，一阶项为 $(-\boldsymbol{A}^{-1}\boldsymbol{E}\boldsymbol{A}^{-1})\boldsymbol{b}+\boldsymbol{A}^{-1}\boldsymbol{f}=\boldsymbol{A}^{-1}(\boldsymbol{f}-\boldsymbol{E}\boldsymbol{x})$，结果相同。

这里只是核对：线性方程有显式的解公式，可微性由显式公式直接得到，不需要隐函数定理。特征方程 $\boldsymbol{S}\boldsymbol{v}=\lambda\boldsymbol{v}$ 则不同，特征值与特征向量一般没有这样的显式公式，必须先用隐函数定理证明局部分支存在且可微，才能求它的响应；第 20.3 节就这样处理。

19.2　反函数的局部存在与微分

隐函数定理还能回答反求输入的问题：已知映射 G 的输出 $\boldsymbol{y}$，能否唯一确定产生它的输入 $\boldsymbol{x}$，并且 $\boldsymbol{x}$ 随 $\boldsymbol{y}$ 光滑变化。例如由直角坐标 (x,y) 反求极坐标 (r,θ)。线性映射 $\boldsymbol{y}=\boldsymbol{M}\boldsymbol{x}$ 可逆当且仅当方阵 $\boldsymbol{M}$ 可逆。非线性映射在

一点附近近似于它的 Jacobian，所以可以期待：Jacobian 可逆时，映射在局部可逆。把 $G(\boldsymbol{x})-\boldsymbol{y}=\boldsymbol{0}$ 看成以输出为参数、输入为待解变量的一组方程，就能使用隐函数定理。所得定理只给出两个邻域之间的逆映射，不断言 G 在整个定义域上单射。

定理 19.5　局部反函数定理　设 $U\subseteq\mathbb{R}^d$ 开，$G:U\to\mathbb{R}^d$ 连续可微，$\boldsymbol{a}\in U$，且 $\boldsymbol{J}_G(\boldsymbol{a})$ 可逆。则存在 $\boldsymbol{a}$ 的开邻域 U_0 与 $G(\boldsymbol{a})$ 的开邻域 V_0，使 $G:U_0\to V_0$ 为双射，逆映射连续可微，并满足

$$\boldsymbol{J}_{G^{-1}}(G(\boldsymbol{x}))=[\boldsymbol{J}_G(\boldsymbol{x})]^{-1}\qquad(\boldsymbol{x}\in U_0).$$

证明　以输出 $\boldsymbol{y}$ 为参数、原输入 $\boldsymbol{x}$ 为待解变量，令 $H(\boldsymbol{y},\boldsymbol{x})=G(\boldsymbol{x})-\boldsymbol{y}$。在 $(G(\boldsymbol{a}),\boldsymbol{a})$ 处，关于 $\boldsymbol{x}$ 的 Jacobian 就是可逆的 $\boldsymbol{J}_G(\boldsymbol{a})$。隐函数定理给出开邻域 V_0、W 以及 C^1 映射 $\varphi:V_0\to W$，使

$$G(\boldsymbol{x})=\boldsymbol{y}\quad\Longleftrightarrow\quad\boldsymbol{x}=\varphi(\boldsymbol{y})\qquad(\boldsymbol{y}\in V_0,\ \boldsymbol{x}\in W).$$

将 W 缩小并重新选取 V_0，可使 $W\subset U$ 且 $\boldsymbol{J}_G$ 在 W 内均可逆。令 $U_0=W\cap G^{-1}(V_0)$，它因 G 连续而为包含 $\boldsymbol{a}$ 的开集。每个 $\boldsymbol{y}\in V_0$ 都有 $G(\varphi(\boldsymbol{y}))=\boldsymbol{y}$，故 $\varphi(\boldsymbol{y})\in U_0$；反之，每个 $\boldsymbol{x}\in U_0$ 都由上述唯一性满足 $\varphi(G(\boldsymbol{x}))=\boldsymbol{x}$。因此 $G:U_0\to V_0$ 为双射，逆就是 C^1 映射 φ。对 $G(\varphi(\boldsymbol{y}))=\boldsymbol{y}$ 使用链式法则，得到 $\boldsymbol{J}_G(\varphi(\boldsymbol{y}))\boldsymbol{J}_\varphi(\boldsymbol{y})=\boldsymbol{I}$，左乘逆矩阵便得到所述公式。 ■

公式说明，逆映射的局部伸缩恰好抵消原映射的局部伸缩。下面用极坐标映射具体验证。

示例 19.6　极坐标的局部反函数　对 $P(r,\theta)=(r\cos\theta,r\sin\theta)^{\mathsf T}$，示例 17.23算得 $\det\boldsymbol{J}_P=r$，所以在 $r>0$ 的每一点附近，都可以从 (x,y) 唯一、光滑地反求 (r,θ)。在 $(r,\theta)=(2,\pi/2)$，即平面上的点 $(0,2)$ 处，

$$\boldsymbol{J}_P=\begin{bmatrix}0&-2\\1&0\end{bmatrix}$$

$$\boldsymbol{J}_{P^{-1}}(0,2)=\boldsymbol{J}_P^{-1}=\begin{bmatrix}0&1\\-1/2&0\end{bmatrix}.$$

第一行说明 $\mathrm{d}r=\mathrm{d}y$：在正上方的点，向上移动直接增大半径。第二行说明 $\mathrm{d}\theta=-\mathrm{d}x/2$：向左移动使角度增大，且因为半径为 2，角度变化只有水平位移的一半。

在 $r=0$ 处，Jacobian 行列式为零，所有 θ 都映到原点，确实无法反求 θ；这正是定理条件不满足的地方。

局部可逆与整体单射　局部反函数定理是局部结论。即使 Jacobian 处处可逆，映射在整个定义域上也未必单射。

示例 19.7　Jacobian 处处可逆而不单射　考虑映射

$$g(u,v)=(e^u\cos v,\,e^u\sin v)^{\top}$$
$$(u,v)\in\mathbb{R}^2.$$

它的 Jacobian 矩阵为

$$\boldsymbol{J}_g(u,v)=\begin{bmatrix} e^u\cos v & -e^u\sin v \\ e^u\sin v & e^u\cos v \end{bmatrix}$$
$$\det \boldsymbol{J}_g = e^{2u}>0,$$

处处可逆。但 (u,v) 与 $(u,v+2\pi)$ 给出同一输出，g 不是单射。

这个 g 就是半径取 e^u 的极坐标映射。它在每一点附近可以反求，但沿 v 方向每隔 2π 就重复覆盖一次输出。

另一方面，有连续的逆也不保证逆可微。一元函数 $x\mapsto x^3$ 全局单射，其逆 $y\mapsto y^{1/3}$ 在 0 处没有有限导数；这对应 x^3 在 0 处导数为零，定理条件不满足。所以 Jacobian 非奇异的条件不能由整体单射代替；使用局部反函数定理时，邻域、可微性和 Jacobian 的可逆性都要逐项检查。第 21章用坐标变换计算区域积分时（第 21.3节），还须检查所用区域上的一一对应、光滑性和边界的处理，不能仅凭一点处 Jacobian 非零就对整个区域换元。

19.3　本章小结

方程 $F(\boldsymbol{x},\boldsymbol{y})=\boldsymbol{0}$ 在一点附近能否把 $\boldsymbol{y}$ 解成 $\boldsymbol{x}$ 的函数，取决于两件事：先指定一个起始解 $(\boldsymbol{a},\boldsymbol{b})$，再检查关于待解变量的 Jacobian$\boldsymbol{D}_{\boldsymbol{y}}F(\boldsymbol{a},\boldsymbol{b})$ 是否可逆。线性方程说明了这个条件的来源：系数方阵可逆时解唯一，否则解不存在或不唯一。隐函数定理断言，在 F 连续可微、该 Jacobian 可逆时，非线性方程在局部也有唯一的连续可微解分支，导数是 $-(\boldsymbol{D}_{\boldsymbol{y}}F)^{-1}\boldsymbol{D}_{\boldsymbol{x}}F$。

证明把解方程改写为固定斜率的修正迭代，依次核对三件事：修正映射在一个闭球上是压缩，它不把球内的点送出球，所得不动点随参数 Lipschitz 并可微。存在与唯一是定理真正困难的部分；对恒等式 $F(\boldsymbol{x},\varphi(\boldsymbol{x}))=\boldsymbol{0}$ 形式求导，只能在分支已知可微时给出导数公式。

反函数定理是同一机制的特例：把 $G(\boldsymbol{x}) - \boldsymbol{y} = \mathbf{0}$ 中的输出当作参数，$\boldsymbol{J}_G(\boldsymbol{a})$ 可逆时，G 在 $\boldsymbol{a}$ 附近与 $G(\boldsymbol{a})$ 附近的开集之间可逆，逆映射的 Jacobian 是原 Jacobian 的逆。两类问题中，可逆的 Jacobian 都保证线性近似可以唯一地反解，从而局部的非线性问题也可以。

这些结论都是局部的。唯一性只限于所选邻域，远处可以有其他解支；Jacobian 处处可逆的映射仍可能不是整体单射，例如 $(u, v) \mapsto (e^u \cos v, e^u \sin v)$；Jacobian 奇异时定理不作结论，既不能断言分支不存在，也不能默认它光滑。区域积分的换元还要另外检查整个区域上的一一对应。解分支的响应有多大、在有限扰动下一阶近似是否可靠，由下一章讨论。

第 20 章

微分与扰动分析

测量误差、舍入误差或数据的轻微变化，都会让输入偏离理想值。第 7章已经不借助微分，直接比较精确变化 $F(\boldsymbol{x}+\boldsymbol{h})-F(\boldsymbol{x})$，得到线性作用的条件数和谱的有限扰动界；这些界对一切方向取最坏情形。前三章则给出了另一种工具：微分把变化分成对 $\boldsymbol{h}$ 线性的一阶响应和余项。本章把两者结合起来，回答三个问题：沿指定方向改变输入时，输出的一阶响应是什么；在所有允许方向中，误差最多被放大多少倍；对给定的有限步长，线性预测还差多少。

第一节对一般可微映射回答后两个问题。局部条件数用有限变化定义，可微时等于微分在允许方向子空间上的算子范数；余项界则需要导数沿整条扰动线段的变化，得到带明确常数的二次估计。这一节建立的是分析方法，不依赖具体运算。

后两节把这套方法用于矩阵。第二节调用第 18章的微分公式与精确增量，逐个估计基本运算、求逆、行列式和对数行列式的一阶响应、条件数和余项，并检查整条扰动线段是否留在定义域内。第三节处理没有显式公式的输出：用第 19章的隐函数定理证明简单特征值与特征向量的分支可微，计算它们沿指定方向的响应，并说明一阶近似何时可靠。

本章所用的有限扰动界都以第 7章为准，逆矩阵与方程解的完整误差分析以第 14章为准。本章补充的是指定方向的一阶响应与它在有限步长下的精度，不重复那里的稳定性证明，也不评价求解算法。

20.1 一般映射的扰动分析

输入带有误差时，输出会偏离多少？第 17章的微分给出一阶预测：输入改变 $\boldsymbol{h}$ 时，输出的变化约为 $\mathrm{d}F_{\boldsymbol{x}}(\boldsymbol{h})$。把精确变化写成

$$\Delta F = F(\boldsymbol{x}+\boldsymbol{h})-F(\boldsymbol{x}) = \mathrm{d}F_{\boldsymbol{x}}(\boldsymbol{h}) + R_{\boldsymbol{x}}(\boldsymbol{h}),$$

本节回答两个问题：在所有允许方向中，一阶误差最多被放大多少倍；对给定的有限步长，一阶预测还差多少。前一个问题由微分的算子范数回答，后一个问题需要控制导数沿扰动线段的变化。

本节的输入、输出空间都是有限维赋范空间，例如取某种范数的 $\mathbb{R}^d$，或按元素排成坐标的矩阵空间。可微性的定义与 $\mathbb{R}^d$ 中相同；由范数等价（定理 3.27），可微与否不依赖所选范数，只有算子范数的数值依赖范数。

20.1.1 局部条件数与导数范数

先回顾第 7章的结论。对固定矩阵的线性作用 $\boldsymbol{x} \mapsto \boldsymbol{A}\boldsymbol{x}$，输出误差与输入误差之比只依赖扰动方向，在全部方向上取上确界，就得到放大倍数 $\|\boldsymbol{A}\|$；相对误差的最坏放大不超过 $\kappa(\boldsymbol{A}) = \|\boldsymbol{A}\|\|\boldsymbol{A}^{-1}\|$（第 7.1.2节）。这些结论对任意大小的扰动都成立。

一般映射 F 不是线性的，误差比还随扰动大小改变，所以要先在半径为 δ 的小扰动中取最坏情形，再让半径缩小。

固定基点 $\boldsymbol{x}$ 与输入、输出空间的范数，并设 F 在 $\boldsymbol{x}$ 的一个开邻域内有定义。若只允许对称扰动等结构化变化，就固定一个非零线性子空间 $\mathcal{E}$ 作为允许的扰动方向，并只在 $\boldsymbol{x} + \mathcal{E}$ 中取邻域；无结构限制时 $\mathcal{E}$ 是整个输入空间。

定义 20.1　局部条件数　F 在 $\boldsymbol{x}$ 处相对于允许子空间 $\mathcal{E}$ 的局部条件数（local condition number），也称局部绝对条件数，定义为

$$\kappa_{\mathrm{abs}}(F, \boldsymbol{x}) = \lim_{\delta \downarrow 0} \sup_{\boldsymbol{h} \in \mathcal{E},\, 0 < \|\boldsymbol{h}\| \le \delta} \frac{\|F(\boldsymbol{x}+\boldsymbol{h}) - F(\boldsymbol{x})\|}{\|\boldsymbol{h}\|}.$$

内层的上确界覆盖全部允许方向，随 δ 减小而不增，所以极限在 $[0, \infty]$ 中存在。定义只用到函数值的有限变化，不要求 F 可微。它也不同于沿某个给定方向的响应：后者只是上确界中的一项，最坏方向上的放大可能大得多。

F 可微时，局部条件数恰好是微分的算子范数。

定理 20.2　可微映射的局部条件数　若 F 在 $\boldsymbol{x}$ 处可微，则

$$\kappa_{\mathrm{abs}}(F, \boldsymbol{x}) = \max_{\boldsymbol{h} \in \mathcal{E},\, \|\boldsymbol{h}\| = 1} \|\mathrm{d}F_{\boldsymbol{x}}(\boldsymbol{h})\|,$$

即微分限制在允许子空间上的算子范数 $\|\mathrm{d}F_{\boldsymbol{x}}|_{\mathcal{E}}\|$。

证明　记余项 $R_{\boldsymbol{x}}(\boldsymbol{h}) = F(\boldsymbol{x}+\boldsymbol{h}) - F(\boldsymbol{x}) - \mathrm{d}F_{\boldsymbol{x}}(\boldsymbol{h})$，并令

$$\eta(\delta) = \sup_{\boldsymbol{h}\in\mathcal{E},\ 0<\|\boldsymbol{h}\|\le\delta} \frac{\|R_{\boldsymbol{x}}(\boldsymbol{h})\|}{\|\boldsymbol{h}\|}.$$

可微性说明 $\boldsymbol{h}\to\boldsymbol{0}$ 时 $\|R_{\boldsymbol{x}}(\boldsymbol{h})\|/\|\boldsymbol{h}\|\to 0$，按极限的定义，$\eta(\delta)\to 0$。记 $N = \|\mathrm{d}F_{\boldsymbol{x}}|_{\mathcal{E}}\|$。一方面，由三角不等式，每个比值不超过 $\|\mathrm{d}F_{\boldsymbol{x}}(\boldsymbol{h})\|/\|\boldsymbol{h}\| + \|R_{\boldsymbol{x}}(\boldsymbol{h})\|/\|\boldsymbol{h}\| \le N + \eta(\delta)$。另一方面，有限维线性映射的算子范数可以取到（第 3.3.4节），取单位向量 $\boldsymbol{h}_0\in\mathcal{E}$ 使 $\|\mathrm{d}F_{\boldsymbol{x}}(\boldsymbol{h}_0)\| = N$，令 $\boldsymbol{h} = \delta\boldsymbol{h}_0$；由反向三角不等式，这个比值至少为 $N-\eta(\delta)$。所以内层上确界介于 $N-\eta(\delta)$ 与 $N+\eta(\delta)$ 之间，令 $\delta\downarrow 0$ 即得。 ■

所以局部条件数就是最坏方向上的一阶敏感性。若只允许结构化扰动，微分和最坏方向都限制在允许的子空间内，所得数值一般不大于无结构的情形。

相对条件数　输入、输出的参照量均非零时，把绝对条件数乘以输入尺度、除以输出尺度，得到相对条件数

$$\kappa_{\mathrm{rel}}(F,\boldsymbol{x}) = \kappa_{\mathrm{abs}}(F,\boldsymbol{x})\,\frac{\|\boldsymbol{x}\|}{\|F(\boldsymbol{x})\|},$$

它衡量相对扰动在一阶上被放大多少倍。

对固定矩阵的线性作用 $F(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x}$，余项为零，误差比 $\|\boldsymbol{A}\boldsymbol{h}\|/\|\boldsymbol{h}\|$ 与步长无关，局部绝对条件数就是 $\|\boldsymbol{A}\|$，相对条件数是 $\|\boldsymbol{A}\|\|\boldsymbol{x}\|/\|\boldsymbol{A}\boldsymbol{x}\|$。$\boldsymbol{A}$ 可逆时，由 $\|\boldsymbol{x}\| = \|\boldsymbol{A}^{-1}\boldsymbol{A}\boldsymbol{x}\| \le \|\boldsymbol{A}^{-1}\|\|\boldsymbol{A}\boldsymbol{x}\|$，它不超过 $\|\boldsymbol{A}\|\|\boldsymbol{A}^{-1}\| = \kappa(\boldsymbol{A})$，这正回到第 7.1.2节的精确结论。

这里有三个容易混淆的量。矩阵条件数 $\kappa(\boldsymbol{A})$ 对全部输入取最坏情形，是固定线性作用的统一上界；固定输入 $\boldsymbol{x}$ 处的相对条件数只涉及这一点；把矩阵本身当作输入时，某个矩阵映射（例如求逆）的条件数又是另一个问题，第 20.2节将具体计算。它们描述的都是数学问题本身对输入变化的敏感性；问题条件数与求解算法稳定性的分工见第 14.1.2节，二者不能互相代替。

有限条件数而不可微　条件数有限并不要求可微。取实对称矩阵 $\boldsymbol{S}(t) = \mathrm{diag}(t,-t)$，把 $t\in\mathbb{R}$ 作为标量输入，输出取排序后的最大特征值 $\lambda_{\max}(\boldsymbol{S}(t)) = |t|$，两端都用绝对值度量。由 Weyl 界（定理 7.10），

$$|\lambda_{\max}(\boldsymbol{S}(t)) - \lambda_{\max}(\boldsymbol{S}(s))| \le \|\boldsymbol{S}(t)-\boldsymbol{S}(s)\|_2 = |t-s|,$$

有限变化受到控制；在 $t=0$ 处，比值 $|\lambda_{\max}(\boldsymbol{S}(h))-0|/|h|$ 恒为 1，所以局部绝对条件数为 1。可是 $|t|$ 在 0 处没有双侧导数，这个条件数不能用微分的范数解释。失去可微性的是“排序后取最大”这一步：两条未排序的特征值分支 t 与 $-t$ 本身光滑，它们在 $t=0$ 相交，最大值在交点处从一支换到另一支。第 20.3节将在特征值简单的条件下，证明所选的局部分支可微。

反过来，局部条件数为零也不说明输出不变。$f(t)=t^2$ 在 0 处导数为零，局部条件数为 0，但有限步长 t 仍带来变化 t^2。一阶分析在这里预测“没有变化”，被遗漏的部分要由下一小节的余项界估计。

20.1.2 一阶近似的余项界

可微性只保证余项是 $o(\|\boldsymbol{h}\|)$，并不给出某个有限扰动的数值误差界。要得到这样的界，需要知道导数沿扰动线段怎样变化。本小节输入、输出都取欧氏范数，矩阵空间取 Frobenius 范数，即拉直后的欧氏范数；导数的大小用谱范数度量。其他范数下可借范数等价改变常数。

设 F 在包含线段 $[\boldsymbol{x},\boldsymbol{x}+\boldsymbol{h}]$ 的开集上连续可微。式 (17.11)给出完整增量 $\int_0^1 \boldsymbol{J}_F(\boldsymbol{x}+t\boldsymbol{h})\boldsymbol{h}\,\mathrm{d}t$；从中扣除常向量 $\boldsymbol{J}_F(\boldsymbol{x})\boldsymbol{h}=\int_0^1 \boldsymbol{J}_F(\boldsymbol{x})\boldsymbol{h}\,\mathrm{d}t$，得到余项的精确表示

$$R_{\boldsymbol{x}}(\boldsymbol{h})=F(\boldsymbol{x}+\boldsymbol{h})-F(\boldsymbol{x})-\boldsymbol{J}_F(\boldsymbol{x})\boldsymbol{h}=\int_0^1 \big(\boldsymbol{J}_F(\boldsymbol{x}+t\boldsymbol{h})-\boldsymbol{J}_F(\boldsymbol{x})\big)\boldsymbol{h}\,\mathrm{d}t. \tag{20.1}$$

对照两种估计：完整增量由沿线段的导数大小 $\|\boldsymbol{J}_F\|_2$ 控制（式 (17.10)），余项则由导数相对基点的变化 $\|\boldsymbol{J}_F(\boldsymbol{x}+t\boldsymbol{h})-\boldsymbol{J}_F(\boldsymbol{x})\|_2$ 控制。导数很大而变化很慢时，整个增量可以很大，一阶预测却仍然准确；二者估计的是不同对象。

定理 20.3 一阶近似的二次余项界 设 F 在包含线段 $[\boldsymbol{x},\boldsymbol{x}+\boldsymbol{h}]$ 的开集上连续可微，且存在常数 $L\ge 0$，使

$$\|\boldsymbol{J}_F(\boldsymbol{y})-\boldsymbol{J}_F(\boldsymbol{x})\|_2\le L\|\boldsymbol{y}-\boldsymbol{x}\|_2 \qquad (\boldsymbol{y}\in[\boldsymbol{x},\boldsymbol{x}+\boldsymbol{h}]).$$

则

$$\|F(\boldsymbol{x}+\boldsymbol{h})-F(\boldsymbol{x})-\boldsymbol{J}_F(\boldsymbol{x})\boldsymbol{h}\|_2\le\frac{L}{2}\|\boldsymbol{h}\|_2^2.$$

证明 取 $\boldsymbol{y}=\boldsymbol{x}+t\boldsymbol{h}$，假设给出 $\|\boldsymbol{J}_F(\boldsymbol{x}+t\boldsymbol{h})-\boldsymbol{J}_F(\boldsymbol{x})\|_2\le Lt\|\boldsymbol{h}\|_2$。对式 (20.1)使用向量积分的范数不等式与谱范数的界，

$$\|R_{\boldsymbol{x}}(\boldsymbol{h})\|_2\le\int_0^1\big\|\big(\boldsymbol{J}_F(\boldsymbol{x}+t\boldsymbol{h})-\boldsymbol{J}_F(\boldsymbol{x})\big)\boldsymbol{h}\big\|_2\,\mathrm{d}t\le\int_0^1 Lt\|\boldsymbol{h}\|_2^2\,\mathrm{d}t=\frac{L}{2}\|\boldsymbol{h}\|_2^2.$$

■

定理只要求一阶导数相对基点满足 Lipschitz 型的界，不以 Hessian 或二阶导数的存在为前提。若 $\boldsymbol{J}_F$ 在一个凸邻域内以 L 为 Lipschitz 常数，邻域内每条线段都满足假设。定理 17.34已说明，$F \in C^2$ 时二阶导数的统一界 M 就是这样的常数，于是余项不超过 $M\|\boldsymbol{h}\|_2^2/2$；这是取得该条件的一种充分办法。

上界正比于 $\|\boldsymbol{h}\|_2^2$：步长缩小到一半，上界缩小到四分之一。这说明的是所保证误差的量级，并不意味着实际误差恰好按同样比例变化，实际误差也可能远小于上界。例如对称二次型 $q(\boldsymbol{x}) = \boldsymbol{x}^{\top}\boldsymbol{S}\boldsymbol{x}$ 的 Jacobian 是 $\nabla q^{\top} = 2\boldsymbol{x}^{\top}\boldsymbol{S}$，满足 $\|2\boldsymbol{S}\boldsymbol{y} - 2\boldsymbol{S}\boldsymbol{x}\|_2 \le 2\|\boldsymbol{S}\|_2\|\boldsymbol{y} - \boldsymbol{x}\|_2$；定理给出余项界 $\|\boldsymbol{S}\|_2\|\boldsymbol{h}\|_2^2$，与第 17.2.3节由精确增量得到的 $|\boldsymbol{h}^{\top}\boldsymbol{S}\boldsymbol{h}| \le \|\boldsymbol{S}\|_2\|\boldsymbol{h}\|_2^2$ 一致。

三种保证的分工　可微给出统一的 $o(\|\boldsymbol{h}\|)$，只说明步长趋零时的行为；导数的 Lipschitz 界给出带明确常数的二次余项；第 17.3.3节的导数界则控制整个有限变化。

使用后两者之前都要先检查：扰动线段是否留在定义域内，可逆、正定等结构条件是否在整条线段上保持，所需常数是否在这个范围内统一成立。矩阵映射的这些检查可以借助已有的有限扰动结论：第 7章的 Weyl 界与奇异值扰动界判断正定性与可逆性是否保持，第 14.1.1节的逆矩阵有限界控制求逆在整段上的变化。基点的条件数只描述无穷小扰动，不能代替这些范围检查和余项估计；下一节对各种矩阵运算逐一完成这些检查。

20.2　矩阵运算的扰动分析

第 18章已经求出常用矩阵运算的微分，并用增量的一阶项验证了可微性。本节回到误差问题：矩阵数据带有扰动 $\boldsymbol{E}$ 时，这些微分给出的线性预测在有限步长下有多准，误差在最坏方向上被放大多少。

对每种运算都要同时检查三件事：输出是矩阵还是标量，因而误差用什么范数或尺度度量；扰动是否受对称等结构限制；整条扰动线段是否留在定义域内。前一节的一般原则在这里落到具体的余项表达式上。本节的矩阵范数除特别说明外取满足乘积不等式 $\|\boldsymbol{X}\boldsymbol{Y}\| \le \|\boldsymbol{X}\|\|\boldsymbol{Y}\|$ 的范数，例如谱范数或 Frobenius 范数；求逆时取由向量范数诱导的矩阵范数，它还满足 $\|\boldsymbol{I}\| = 1$。

20.2.1 基本矩阵运算的增量与余项

第 18.2节对转置、乘法、平方、迹、Frobenius 范数平方和二次型写出了精确增量。这些增量都是扰动的多项式，所以余项不必另行估计，直接从增量中读出，再用范数控制大小。

线性运算 加法、数乘、转置、迹以及 $\boldsymbol{X} \mapsto \boldsymbol{A}\boldsymbol{X}\boldsymbol{B}$ 都是线性映射，精确增量就是一阶项，余项恒为零。对这些运算，线性预测在任意步长下都精确，误差问题只剩放大倍数。由定理 20.2，局部绝对条件数就是运算本身的算子范数，且与基点无关。

例如在 Frobenius 范数下，转置不改变任何矩阵的长度，条件数为 1。迹则不同：由 Cauchy–Schwarz 不等式，$|\operatorname{tr} \boldsymbol{E}| = |\langle \boldsymbol{I}, \boldsymbol{E}\rangle_F| \le \sqrt{d}\,\|\boldsymbol{E}\|_F$，取 $\boldsymbol{E} = \boldsymbol{I}/\sqrt{d}$ 时等号成立，所以 $d \times d$ 矩阵的迹的条件数为 $\sqrt{d}$。各对角元的误差同号时会累加起来。

乘积与平方 由式 (18.3)，两个因子同时扰动时，

$$(\boldsymbol{A}+\boldsymbol{E})(\boldsymbol{B}+\boldsymbol{H}) - \boldsymbol{A}\boldsymbol{B} - (\boldsymbol{A}\boldsymbol{H}+\boldsymbol{E}\boldsymbol{B}) = \boldsymbol{E}\boldsymbol{H}.$$

一阶项满足 $\|\boldsymbol{A}\boldsymbol{H}+\boldsymbol{E}\boldsymbol{B}\| \le \|\boldsymbol{A}\|\|\boldsymbol{H}\| + \|\boldsymbol{E}\|\|\boldsymbol{B}\|$，余项满足 $\|\boldsymbol{E}\boldsymbol{H}\| \le \|\boldsymbol{E}\|\|\boldsymbol{H}\|$。两者的比较说明：两个扰动都不超过 ρ 时，一阶项至多与 ρ 同阶，余项至多是 ρ^2。平方映射同理，$(\boldsymbol{X}+\boldsymbol{E})^2 - \boldsymbol{X}^2$ 的一阶项为 $\boldsymbol{X}\boldsymbol{E}+\boldsymbol{E}\boldsymbol{X}$，余项恰为 $\boldsymbol{E}^2$，$\|\boldsymbol{E}^2\| \le \|\boldsymbol{E}\|^2$。

这些界可以直接用作误差预算。若要求线性预测的绝对误差不超过 τ，乘积情形只需 $\|\boldsymbol{E}\|\|\boldsymbol{H}\| \le \tau$，两个扰动同样大小时步长不超过 $\sqrt{\tau}$ 即可。若要求余项不超过一阶项的某个比例，则还要知道一阶项在所取方向上有多大，不能只看扰动的大小。

示例 20.4 矩阵平方的一阶预测 取 $\boldsymbol{X} = \operatorname{diag}(2,1)$ 与扰动 $\boldsymbol{E} = \varepsilon \boldsymbol{K}$，其中

$$\boldsymbol{K} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}.$$

一阶项为 $\boldsymbol{X}\boldsymbol{E}+\boldsymbol{E}\boldsymbol{X} = \varepsilon \begin{bmatrix} 0 & 3 \\ 3 & 0 \end{bmatrix}$，谱范数为 3ε；余项为 $\boldsymbol{E}^2 = \varepsilon^2 \boldsymbol{I}$，谱范数为 ε^2。取 $\varepsilon = 0.1$，一阶项为 0.3，余项为 0.01，约为一阶项的 3%。若要求余项不超过一阶项的 1%，由 $\varepsilon^2/(3\varepsilon) \le 0.01$，扰动须满足 $\varepsilon \le 0.03$。

Frobenius 范数平方与二次型　标量输出的运算同样可以读出余项。Frobenius 范数平方的精确增量为 $2\langle \boldsymbol{X}, \boldsymbol{E}\rangle_F + \|\boldsymbol{E}\|_F^2$，余项恰为 $\|\boldsymbol{E}\|_F^2$，与方向无关。一阶项 $2\langle \boldsymbol{X}, \boldsymbol{E}\rangle_F$ 却可能为零：扰动与 $\boldsymbol{X}$ 正交时，线性预测说“没有变化”，实际变化却是 $\|\boldsymbol{E}\|_F^2$。这时余项与一阶项之比没有意义，应直接给出绝对误差的预算。

二次型 $\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}$ 在 $\boldsymbol{A}$ 与 $\boldsymbol{x}$ 同时扰动时，第 18.2节写出的余项为 $\boldsymbol{h}^\top \boldsymbol{A}\boldsymbol{h} + \boldsymbol{x}^\top \boldsymbol{E}\boldsymbol{h} + \boldsymbol{h}^\top \boldsymbol{E}\boldsymbol{x} + \boldsymbol{h}^\top \boldsymbol{E}\boldsymbol{h}$。在谱范数下，它的绝对值不超过

$$\|\boldsymbol{A}\|_2\|\boldsymbol{h}\|_2^2 + 2\|\boldsymbol{E}\|_2\|\boldsymbol{x}\|_2\|\boldsymbol{h}\|_2 + \|\boldsymbol{E}\|_2\|\boldsymbol{h}\|_2^2.$$

每一项都含两个扰动因子，其中 $\|\boldsymbol{E}\|_2\|\boldsymbol{h}\|_2$ 一项还乘了基点的大小 $\|\boldsymbol{x}\|_2$：基点越大，矩阵与向量扰动的交叉作用越强。

比较起来，线性运算的余项为零，多项式运算的余项是扰动的二次或更高次项，并且可以精确写出。误差预算由这些高次项决定线性预测可用的步长；导数本身的大小只决定一阶项，不决定预测还差多少。

20.2.2　求逆的扰动

第 18.3节由逆差恒等式证明了求逆可微，并得到 $\mathrm{d}(\boldsymbol{X}^{-1}) = -\boldsymbol{X}^{-1}\mathrm{d}\boldsymbol{X}\boldsymbol{X}^{-1}$。那里只用到余项是 $o(\|\boldsymbol{E}\|)$。本节把余项精确写出，给出它的二次界，再计算求逆的条件数，并说明它与线性方程解映射的联系。

精确余项与可逆邻域　设 $\boldsymbol{A}$ 可逆，$\boldsymbol{B} = \boldsymbol{A} + \boldsymbol{E}$，$q = \|\boldsymbol{A}^{-1}\|\|\boldsymbol{E}\| < 1$。由逆差恒等式 (14.1)，$\boldsymbol{B}^{-1} - \boldsymbol{A}^{-1} = -\boldsymbol{B}^{-1}\boldsymbol{E}\boldsymbol{A}^{-1}$。把右端的 $\boldsymbol{B}^{-1}$ 写成 $\boldsymbol{A}^{-1} + (\boldsymbol{B}^{-1} - \boldsymbol{A}^{-1})$，再用一次同一恒等式，

$$\boldsymbol{B}^{-1} - \boldsymbol{A}^{-1} = -\boldsymbol{A}^{-1}\boldsymbol{E}\boldsymbol{A}^{-1} - (\boldsymbol{B}^{-1} - \boldsymbol{A}^{-1})\boldsymbol{E}\boldsymbol{A}^{-1} = -\boldsymbol{A}^{-1}\boldsymbol{E}\boldsymbol{A}^{-1} + \boldsymbol{B}^{-1}\boldsymbol{E}\boldsymbol{A}^{-1}\boldsymbol{E}\boldsymbol{A}^{-1}.$$

第一项是一阶预测，第二项是精确余项。由 $\|\boldsymbol{B}^{-1}\| \le \|\boldsymbol{A}^{-1}\|/(1-q)$（第 14.1.1节），

$$\|\boldsymbol{B}^{-1}\boldsymbol{E}\boldsymbol{A}^{-1}\boldsymbol{E}\boldsymbol{A}^{-1}\| \le \|\boldsymbol{B}^{-1}\|\|\boldsymbol{A}^{-1}\|^2\|\boldsymbol{E}\|^2 \le \frac{\|\boldsymbol{A}^{-1}\|^3\|\boldsymbol{E}\|^2}{1-q}. \tag{20.2}$$

第 8章的 Neumann 级数给出同一结论的另一种看法。写 $\boldsymbol{B} = \boldsymbol{A}(\boldsymbol{I} - \boldsymbol{T})$，其中 $\boldsymbol{T} = -\boldsymbol{A}^{-1}\boldsymbol{E}$，$\|\boldsymbol{T}\| \le q < 1$，因而谱半径小于 1。由定理 8.12，$\boldsymbol{I} - \boldsymbol{T}$ 可逆，$\boldsymbol{B}^{-1} = \sum_{k\ge 0} \boldsymbol{T}^k \boldsymbol{A}^{-1}$。前两项 $\boldsymbol{A}^{-1} - \boldsymbol{A}^{-1}\boldsymbol{E}\boldsymbol{A}^{-1}$ 正是一阶预测；截断误差界 (8.3)取 $N = 1$，给出余项不超过 $q^2\|\boldsymbol{A}^{-1}\|/(1-q)$，与式 (20.2)相同。级数还说明，余项依次由 $\boldsymbol{E}$ 的二次、三次……项组成。

一阶预测的误差 式 (20.2)同时是有限扰动下一阶预测的误差界。对 $0 \le t \le 1$，$\|\boldsymbol{A}^{-1}(t\boldsymbol{E})\| \le tq < 1$，所以整条扰动线段 $\boldsymbol{A} + t\boldsymbol{E}$ 都由可逆矩阵组成，定义域条件在整段上成立。于是可以比较三个量：实际逆矩阵 $(\boldsymbol{A}+\boldsymbol{E})^{-1}$，一阶预测 $\boldsymbol{A}^{-1} - \boldsymbol{A}^{-1}\boldsymbol{E}\boldsymbol{A}^{-1}$，以及二者之差。第 14.1.1节控制的是全变化，$\|(\boldsymbol{A}+\boldsymbol{E})^{-1} - \boldsymbol{A}^{-1}\| \le \|\boldsymbol{A}^{-1}\|^2\|\boldsymbol{E}\|/(1-q)$，与 $\|\boldsymbol{E}\|$ 同阶；本段新增的是从全变化中扣除一阶项之后，近似还差多少，它与 $\|\boldsymbol{E}\|^2$ 同阶。q 接近 1 时两种界都变得很大，一阶预测不再可靠。

示例 20.5 逆矩阵的一阶预测与余项 取 $\boldsymbol{A} = \operatorname{diag}(2, 1)$ 与扰动

$$\boldsymbol{E} = \begin{bmatrix} 0 & 0.1 \\ 0.1 & 0 \end{bmatrix},$$

采用谱范数，则 $\|\boldsymbol{A}^{-1}\|_2 = 1$、$\|\boldsymbol{E}\|_2 = 0.1$、$q = 0.1$。这个矩阵可以直接求逆，

$$(\boldsymbol{A}+\boldsymbol{E})^{-1} = \frac{1}{1.99}\begin{bmatrix} 1 & -0.1 \\ -0.1 & 2 \end{bmatrix},$$

而一阶预测为

$$\boldsymbol{A}^{-1} - \boldsymbol{A}^{-1}\boldsymbol{E}\boldsymbol{A}^{-1} = \begin{bmatrix} 0.5 & -0.05 \\ -0.05 & 1 \end{bmatrix}.$$

实际值减去预测，剩下的余项为

$$\frac{0.0005}{1.99}\begin{bmatrix} 10 & -1 \\ -1 & 20 \end{bmatrix} \approx \begin{bmatrix} 0.00251 & -0.00025 \\ -0.00025 & 0.00503 \end{bmatrix}.$$

现在比较几个量的大小。余项的谱范数约为 0.00505，约为一阶项谱范数 0.05 的十分之一，并落在式 (20.2)的上界 $0.01/0.9 \approx 0.0111$ 之内。全变化 $(\boldsymbol{A}+\boldsymbol{E})^{-1} - \boldsymbol{A}^{-1}$ 的谱范数约为 0.0540，第 14.1.1节的全变化界为 $0.1/0.9 \approx 0.111$。

一阶预测扣除了全变化中约 0.05 的主要部分，剩下的误差约为扰动大小的平方量级；余项界比实际误差大约两倍，它只保证误差不超过多少。

求逆的条件数 在无结构限制的扰动模型下，输入、输出都取谱范数。由乘积不等式，$\|\boldsymbol{A}^{-1}\boldsymbol{E}\boldsymbol{A}^{-1}\|_2 \le \|\boldsymbol{A}^{-1}\|_2^2\|\boldsymbol{E}\|_2$。这个上界可以取到。设 σ_d 是 $\boldsymbol{A}$ 的最小奇异值，对应的左、右奇异向量为 $\boldsymbol{u}_d, \boldsymbol{v}_d$，即 $\boldsymbol{A}\boldsymbol{v}_d = \sigma_d\boldsymbol{u}_d$、

$\boldsymbol{A}^{\top}\boldsymbol{u}_d = \sigma_d \boldsymbol{v}_d$（第 5章）。取 $\boldsymbol{E} = \boldsymbol{u}_d \boldsymbol{v}_d^{\top}$，它的谱范数为 1。由 $\boldsymbol{A}^{-1}\boldsymbol{u}_d = \boldsymbol{v}_d/\sigma_d$ 与 $\boldsymbol{A}^{-\top}\boldsymbol{v}_d = \boldsymbol{u}_d/\sigma_d$，

$$\boldsymbol{A}^{-1}\boldsymbol{E}\boldsymbol{A}^{-1} = (\boldsymbol{A}^{-1}\boldsymbol{u}_d)(\boldsymbol{A}^{-\top}\boldsymbol{v}_d)^{\top} = \frac{\boldsymbol{v}_d \boldsymbol{u}_d^{\top}}{\sigma_d^2},$$

其谱范数为 $1/\sigma_d^2 = \|\boldsymbol{A}^{-1}\|_2^2$。由定理 20.2，求逆映射在 $\boldsymbol{A}$ 处的局部绝对条件数为 $\|\boldsymbol{A}^{-1}\|_2^2$，相对条件数为

$$\|\boldsymbol{A}^{-1}\|_2^2 \cdot \frac{\|\boldsymbol{A}\|_2}{\|\boldsymbol{A}^{-1}\|_2} = \|\boldsymbol{A}\|_2 \|\boldsymbol{A}^{-1}\|_2 = \kappa_2(\boldsymbol{A}).$$

矩阵条件数在这里重新出现，但含义不同：这里输入是矩阵本身，输出是逆矩阵，而第 7.1.3节的输入是向量。若限制扰动结构，例如只允许对称扰动，须改用微分在允许子空间上的范数。求解方程的算法及其数值稳定性仍按第 14章处理。

线性方程的解映射　求逆与乘法复合，得到线性方程的解映射

$$\operatorname{sol}(\boldsymbol{A}, \boldsymbol{b}) = \boldsymbol{A}^{-1}\boldsymbol{b},$$

它定义在可逆 $\boldsymbol{A}$ 与任意 $\boldsymbol{b}$ 组成的开集上。固定可逆的 $\boldsymbol{A}$，记 $\boldsymbol{x} = \boldsymbol{A}^{-1}\boldsymbol{b}$；联合输入 $(\boldsymbol{E}, \boldsymbol{f})$ 取乘积范数 $\|(\boldsymbol{E}, \boldsymbol{f})\| = (\|\boldsymbol{E}\|^2 + \|\boldsymbol{f}\|^2)^{1/2}$，其中 $\boldsymbol{f}$ 是右端的增量。第 14.1.1节从 $(\boldsymbol{A}+\boldsymbol{E})(\boldsymbol{x}+\Delta\boldsymbol{x}) = \boldsymbol{b}+\boldsymbol{f}$ 中减去 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$，得到 $(\boldsymbol{A}+\boldsymbol{E})\Delta\boldsymbol{x} = \boldsymbol{f} - \boldsymbol{E}\boldsymbol{x}$。在 $q < 1$ 时，这给出精确式

$$\Delta\boldsymbol{x} = (\boldsymbol{A}+\boldsymbol{E})^{-1}(\boldsymbol{f} - \boldsymbol{E}\boldsymbol{x}).$$

把 $(\boldsymbol{A}+\boldsymbol{E})^{-1}$ 拆成 $\boldsymbol{A}^{-1}$ 与逆差，

$$\Delta\boldsymbol{x} = \boldsymbol{A}^{-1}(\boldsymbol{f} - \boldsymbol{E}\boldsymbol{x}) + \big((\boldsymbol{A}+\boldsymbol{E})^{-1} - \boldsymbol{A}^{-1}\big)(\boldsymbol{f} - \boldsymbol{E}\boldsymbol{x}).$$

第一项对 $(\boldsymbol{E}, \boldsymbol{f})$ 线性。第二项中，逆差的范数不超过 $\|\boldsymbol{A}^{-1}\|^2\|\boldsymbol{E}\|/(1-q)$，又 $\|\boldsymbol{f} - \boldsymbol{E}\boldsymbol{x}\| \le \|\boldsymbol{f}\| + \|\boldsymbol{E}\|\|\boldsymbol{x}\|$；二者都不超过联合扰动大小的常数倍，所以第二项是联合扰动的二次量。因此解映射可微，且

$$\mathrm{d}\operatorname{sol}_{(\boldsymbol{A},\boldsymbol{b})}(\boldsymbol{E}, \boldsymbol{f}) = \boldsymbol{A}^{-1}(\boldsymbol{f} - \boldsymbol{E}\boldsymbol{x}). \tag{20.3}$$

也可以用链式法则核对：sol 是求逆与矩阵—向量乘法的复合，由乘积的联合微分与式 (18.4)，一阶项为 $(-\boldsymbol{A}^{-1}\boldsymbol{E}\boldsymbol{A}^{-1})\boldsymbol{b} + \boldsymbol{A}^{-1}\boldsymbol{f} = \boldsymbol{A}^{-1}(\boldsymbol{f} - \boldsymbol{E}\boldsymbol{x})$，结果相同。第 19.1节已用隐函数公式核对过同一结果。

第 14.1.1节的界控制完整的解误差，式 (20.3)则提取局部的一阶预测，上面的拆分还说明预测的误差是联合扰动的二次量。数据误差、残差与算法稳定性的完整分析仍以第 14章为准，本节只补充一阶响应及其精度。

20.2.3 行列式的扰动

第 18.4节逐列展开 $\det(\boldsymbol{A}+\boldsymbol{E})$，得到一阶项 $\langle \boldsymbol{C}, \boldsymbol{E}\rangle_F$，其中 $\boldsymbol{C}$ 是代数余子式矩阵；展开中其余各项至少含两列扰动。这些高阶项就是线性预测的误差。它们对包括奇异矩阵在内的全部方阵都有意义，所以先讨论绝对误差，再在可逆时讨论相对误差。

绝对变化的余项 在固定的有界邻域内，余项有二次控制。记 $K=\{\boldsymbol{A}+\boldsymbol{F}:\|\boldsymbol{F}\|_F\le 1\}$。行列式的二阶偏导数都是多项式，在闭有界集 K 上有界，所以存在 M 使 $\|D^2\det_{\boldsymbol{Z}}\|\le M$ 对 $\boldsymbol{Z}\in K$ 成立。对 $\|\boldsymbol{E}\|_F\le 1$，令 $g(t)=\det(\boldsymbol{A}+t\boldsymbol{E})$，它是 t 的多项式，且 $g''(t)=D^2\det_{\boldsymbol{A}+t\boldsymbol{E}}[\boldsymbol{E},\boldsymbol{E}]$，于是 $|g''(t)|\le M\|\boldsymbol{E}\|_F^2$。一元 Taylor 公式给出

$$\left|\det(\boldsymbol{A}+\boldsymbol{E})-\det\boldsymbol{A}-\langle \boldsymbol{C},\boldsymbol{E}\rangle_F\right|\le \frac{M}{2}\|\boldsymbol{E}\|_F^2,$$

常数 M 依赖所取的邻域。

二阶情形可以精确写出余项。对 $\boldsymbol{A},\boldsymbol{E}\in\mathbb{R}^{2\times 2}$，直接展开得

$$\det(\boldsymbol{A}+\boldsymbol{E})=\det\boldsymbol{A}+\langle \boldsymbol{C},\boldsymbol{E}\rangle_F+\det\boldsymbol{E},$$

余项就是 $\det\boldsymbol{E}=E_{1,1}E_{2,2}-E_{1,2}E_{2,1}$。由 $|ab|\le (a^2+b^2)/2$，$|\det\boldsymbol{E}|\le\|\boldsymbol{E}\|_F^2/2$，即上式中可取 $M=1$，而且这个界与基点 $\boldsymbol{A}$ 无关，奇异的 $\boldsymbol{A}$ 也适用。

条件数与相对变化 对给定扰动方向，一阶响应是 $\langle \boldsymbol{C},\boldsymbol{E}\rangle_F$。由定理 20.2，局部绝对条件数是这个线性泛函在所选输入范数下的大小，即第 3.3.5节的对偶范数：

$$\kappa_{\mathrm{abs}}(\det,\boldsymbol{A})=\max_{\|\boldsymbol{E}\|\le 1}|\langle \boldsymbol{C},\boldsymbol{E}\rangle_F|.$$

输入取 Frobenius 范数时，由 Cauchy–Schwarz 不等式，$\boldsymbol{C}\neq\boldsymbol{0}$ 时最大值在 $\boldsymbol{E}=\boldsymbol{C}/\|\boldsymbol{C}\|_F$ 处取到，所以 $\kappa_{\mathrm{abs}}=\|\boldsymbol{C}\|_F$，可以直接由代数余子式算出。可逆时还可以比较相对变化：由 $\boldsymbol{C}=\det(\boldsymbol{A})\boldsymbol{A}^{-\mathsf{T}}$，

$$\kappa_{\mathrm{rel}}(\det,\boldsymbol{A})=\|\boldsymbol{C}\|_F\frac{\|\boldsymbol{A}\|_F}{|\det\boldsymbol{A}|}=\|\boldsymbol{A}^{-1}\|_F\|\boldsymbol{A}\|_F.$$

奇异点处 $\det\boldsymbol{A}=0$，只有绝对变化有定义，不能除以零行列式。

在相对尺度下，行列式对矩阵变化的反应可以远比矩阵本身的变化剧烈。

示例 20.6　接近奇异时的行列式　设 $\boldsymbol{A}=\operatorname{diag}(1,\varepsilon)$，$0<\varepsilon<1$，它的行列式 $\det\boldsymbol{A}=\varepsilon$ 很小。只改动第二个对角元，取扰动 $\boldsymbol{E}=\operatorname{diag}(0,\delta)$，使它变为 $\varepsilon+\delta$。矩阵采用谱范数、标量采用绝对值时，矩阵的相对变化为 $\|\boldsymbol{E}\|_2/\|\boldsymbol{A}\|_2=|\delta|$；行列式则变为 $\varepsilon+\delta$，相对变化为

$$\frac{|(\varepsilon+\delta)-\varepsilon|}{\varepsilon}=\frac{|\delta|}{\varepsilon}.$$

用微分公式计算也得到同样的增量：$\det(\boldsymbol{A})\operatorname{tr}(\boldsymbol{A}^{-1}\boldsymbol{E})=\varepsilon\cdot\delta/\varepsilon=\delta$。沿这个方向，行列式是 δ 的一次函数，所以一阶预测没有余项。

两相比较，行列式的相对变化是矩阵相对变化的 $1/\varepsilon$ 倍。ε 越小，矩阵越接近奇异，沿这个方向的相对放大就越强。

但不能仅凭行列式的数值判断求逆是否病态。取 $\boldsymbol{A}=\varepsilon\boldsymbol{I}\in\mathbb{R}^{d\times d}$（$\varepsilon>0$），行列式 ε^d 可以极小，而由第 20.2.2节，求逆的相对条件数是 $\kappa_2(\varepsilon\boldsymbol{I})=1$；行列式本身的相对条件数 $\|\boldsymbol{A}^{-1}\|_F\|\boldsymbol{A}\|_F=d$ 也不随 ε 变大。行列式与逆矩阵是两个不同的输出，绝对与相对又是两种尺度，必须分别判断。

20.2.4　对数行列式的扰动

由第 18.5节，$\log\det$ 在 $\det>0$ 的开集上可微，微分为 $\boldsymbol{E}\mapsto\operatorname{tr}(\boldsymbol{A}^{-1}\boldsymbol{E})$。它给出一阶变化：

$$\log\det(\boldsymbol{A}+\boldsymbol{E})-\log\det\boldsymbol{A}=\operatorname{tr}(\boldsymbol{A}^{-1}\boldsymbol{E})+o(\|\boldsymbol{E}\|_F).$$

相应的局部绝对条件数是线性泛函 $\boldsymbol{E}\mapsto\langle\boldsymbol{A}^{-\top},\boldsymbol{E}\rangle_F$ 在所选输入范数下的对偶范数，Frobenius 范数下为 $\|\boldsymbol{A}^{-1}\|_F$。对数行列式可以为零或接近零，这时以它为分母的相对误差没有意义，应直接比较绝对变化。

整条线段的定义域　要把一阶预测用于有限扰动，先要保证整条线段 $\boldsymbol{A}+t\boldsymbol{E}$（$0\le t\le 1$）留在定义域内。一般的正行列式矩阵，由行列式的连续性，总可以选足够小的邻域，使整条线段 $\boldsymbol{A}+t\boldsymbol{E}$ 仍满足 $\det>0$，但这不给出邻域的具体大小。正定情形则可以用第 7章的最小特征值界明确检查整条线段保持正定，下面的余项界就基于这一检查。

二次余项界　设 $\boldsymbol{A}$ 对称正定，最小特征值为 $m>0$，$\boldsymbol{E}$ 对称且 $\|\boldsymbol{E}\|_2<m$。对任意单位向量 $\boldsymbol{x}$ 和 $0\le t\le 1$，$\boldsymbol{x}^{\top}(\boldsymbol{A}+t\boldsymbol{E})\boldsymbol{x}\ge m-\|\boldsymbol{E}\|_2>0$，所以整条线段保持正定，而且最小特征值有统一的正下界。令 $g(t)=\log\det(\boldsymbol{A}+t\boldsymbol{E})$。由式 (18.6)与链式法则，$g'(t)=\operatorname{tr}\big((\boldsymbol{A}+t\boldsymbol{E})^{-1}\boldsymbol{E}\big)$；再用沿参数曲线的求逆公式，

$$g''(t)=-\operatorname{tr}\big((\boldsymbol{A}+t\boldsymbol{E})^{-1}\boldsymbol{E}(\boldsymbol{A}+t\boldsymbol{E})^{-1}\boldsymbol{E}\big).$$

逆矩阵的谱范数至多为 $(m-\|\boldsymbol{E}\|_2)^{-1}$。由 Frobenius 内积的 Cauchy–Schwarz 不等式与混合乘积界 (3.3)，$|g''(t)| \le \|(\boldsymbol{A}+t\boldsymbol{E})^{-1}\boldsymbol{E}\|_F^2 \le \|\boldsymbol{E}\|_F^2/(m-\|\boldsymbol{E}\|_2)^2$。于是一元 Taylor 公式给出

$$\left|\log\det(\boldsymbol{A}+\boldsymbol{E}) - \log\det\boldsymbol{A} - \operatorname{tr}(\boldsymbol{A}^{-1}\boldsymbol{E})\right| \le \frac{\|\boldsymbol{E}\|_F^2}{2(m-\|\boldsymbol{E}\|_2)^2}.$$

例如 $\boldsymbol{A}=\operatorname{diag}(2,1)$，$\boldsymbol{E}=\operatorname{diag}(0.1,0)$ 时，一阶预测为 0.05，实际变化为 $\log(1.05)\approx 0.04879$。此时 $m=1$，上述上界约为 0.00618，大于实际误差约 0.00121。这个界只保证误差不超过多少，不表示误差会接近上界。导数给出变化的方向与大小，正定线段给出估计的有效范围，余项界说明预测的可靠程度，三者要一起使用。正定条件是这一显式估计的条件，不是一般正行列式矩阵上 $\log\det$ 的定义条件。

上界的分母 $m-\|\boldsymbol{E}\|_2$ 是扰动后最小特征值的保底下界，即到奇异边界的余量。$\boldsymbol{A}$ 接近奇异时，m 很小：一阶响应的条件数 $\|\boldsymbol{A}^{-1}\|_F \ge 1/m$ 变大，余项界又按 $1/(m-\|\boldsymbol{E}\|_2)^2$ 放大，允许的步长必须小于 m。例如 $\boldsymbol{A}=\operatorname{diag}(1,\varepsilon)$、$\boldsymbol{E}=\operatorname{diag}(0,\delta)$ 时，精确变化是 $\log(1+\delta/\varepsilon)$，一阶预测是 δ/ε；δ 与 ε 同阶时两者相差显著，$\delta\to-\varepsilon$ 时精确值趋于 $-\infty$。

20.3 特征值与特征向量的微分

特征值和特征向量由方程 $\boldsymbol{S}\boldsymbol{v}=\lambda\boldsymbol{v}$ 确定，并不是矩阵元素的显式函数，前一节的显式计算不能直接使用。第 7章已经给出有限扰动下的稳定性界：对称扰动 $\boldsymbol{E}$ 使每个排序后的特征值至多移动 $\|\boldsymbol{E}\|_2$（Weyl 界，定理 7.10），特征子空间的偏转受 $\|\boldsymbol{E}\|_2$ 与谱隙之比控制（第 7.2.3节）。这些界对一切方向取最坏情形。

本节回答另一个问题：沿一个指定的扰动方向，特征值与特征向量以什么速率变化，这个变化率在多大范围内可以用来预测。先用第 19章的隐函数定理证明简单特征值所在的分支可微，再分别计算特征值与特征向量的微分，最后说明一阶近似的适用条件。

20.3.1 特征值与特征向量的可微性

设实对称矩阵 $\boldsymbol{S}_0\in\mathbb{R}^{d\times d}$ 有一个简单特征值 λ_0，对应单位特征向量 $\boldsymbol{v}_0$。简单是指这个特征值的代数重数为 1；对实对称矩阵，这等价于其特征空间是一维的。即使规定长度为 1，$\boldsymbol{v}_0$ 和 $-\boldsymbol{v}_0$ 仍代表同一方向。为了在局部选定一支，我们要求附近的向量 $\boldsymbol{v}$ 满足 $\boldsymbol{v}_0^{\top}\boldsymbol{v}>0$。这里选出的只是一个局部分支，单位长度本身并不保证全局唯一。

把对称矩阵 $\boldsymbol{S}$ 作为参数，选取其上三角元素作为独立坐标，便可把对称矩阵空间视为有限维欧氏空间。把向量 $\boldsymbol{v}$ 和标量 λ 作为未知量，特征方程与单位长度条件合起来写成

$$F(\boldsymbol{S},\boldsymbol{v},\lambda)=\begin{pmatrix}\boldsymbol{S}\boldsymbol{v}-\lambda\boldsymbol{v}\\ (\boldsymbol{v}^{\top}\boldsymbol{v}-1)/2\end{pmatrix}=\boldsymbol{0}.$$

这是 $d+1$ 个方程、$d+1$ 个未知量。在 $(\boldsymbol{S}_0,\boldsymbol{v}_0,\lambda_0)$ 处，关于 $(\boldsymbol{v},\lambda)$ 的导数作用于 $(\boldsymbol{h},\eta)$，其矩阵为

$$\begin{pmatrix}\boldsymbol{S}_0-\lambda_0\boldsymbol{I} & -\boldsymbol{v}_0\\ \boldsymbol{v}_0^{\top} & 0\end{pmatrix}.$$

要用隐函数定理，需验证这个方阵可逆，即它只把零向量映为零。设它把 $(\boldsymbol{h},\eta)$ 映为零。先用 $\boldsymbol{v}_0^{\top}$ 左乘第一行，利用对称性及 $\boldsymbol{S}_0\boldsymbol{v}_0=\lambda_0\boldsymbol{v}_0$ 得到 $\eta=0$；第二行给出 $\boldsymbol{v}_0^{\top}\boldsymbol{h}=0$。此时 $\boldsymbol{h}$ 既属于 λ_0 的特征空间，又与 $\boldsymbol{v}_0$ 正交。由于特征值简单，只能有 $\boldsymbol{h}=\boldsymbol{0}$。因此这个方阵可逆，隐函数定理保证在 $\boldsymbol{S}_0$ 附近存在可微的特征值和单位特征向量分支；上述内积为正的条件固定了局部符号。

这里固定符号的条件不能省略。若不选定符号，同一个特征方向可以由 $\boldsymbol{v}_0$ 或 $-\boldsymbol{v}_0$ 表示，沿扰动路径任意切换符号会让“特征向量”看起来不连续；这种跳跃来自表示的不唯一，而不是特征方向本身的变化。选定 $\boldsymbol{v}_0^{\top}\boldsymbol{v}>0$ 以后，隐函数定理给出的分支在邻域内唯一，可微性才有确定的含义。

20.3.2　特征值的微分

有了可微分支，就可以求它对每个小的对称扰动方向的一阶响应。设对称扰动方向 $\boldsymbol{E}$ 使特征值与特征向量分别产生一阶变化 $\mathrm{d}\lambda(\boldsymbol{E})$ 和 $\mathrm{d}\boldsymbol{v}(\boldsymbol{E})$。对特征方程与归一化条件求微分，并在基点取值，得到

$$\begin{aligned}(\boldsymbol{S}_0-\lambda_0\boldsymbol{I})\,\mathrm{d}\boldsymbol{v}(\boldsymbol{E})&=-\big(\boldsymbol{E}-\mathrm{d}\lambda(\boldsymbol{E})\boldsymbol{I}\big)\boldsymbol{v}_0\\ \boldsymbol{v}_0^{\top}\,\mathrm{d}\boldsymbol{v}(\boldsymbol{E})&=0.\end{aligned}$$

用 $\boldsymbol{v}_0^{\top}$ 左乘第一式，左侧为零，于是

$$\mathrm{d}\lambda(\boldsymbol{E})=\boldsymbol{v}_0^{\top}\boldsymbol{E}\boldsymbol{v}_0.$$

这里的微分作用于全部小的对称方向；可微分支的存在由上一小节的隐函数定理保证，对特征方程形式求导本身不能承担这一步。

公式说明，特征值的变化率只看扰动在该特征方向上的读数 $\boldsymbol{v}_0^{\top}\boldsymbol{E}\boldsymbol{v}_0$。由 $\|\boldsymbol{v}_0\|_2=1$ 与谱范数的定义，$|\mathrm{d}\lambda(\boldsymbol{E})|\le\|\boldsymbol{E}\|_2$，等号在 $\boldsymbol{E}=\boldsymbol{v}_0\boldsymbol{v}_0^{\top}$ 时取到，所

以简单特征值分支的局部绝对条件数（谱范数下）为 1。与扰动方向正交的部分，例如满足 $\boldsymbol{E}\boldsymbol{v}_0 = \boldsymbol{0}$ 的扰动，一阶上不改变这个特征值。

示例 20.7　特征值沿两个方向的变化　取 $\boldsymbol{S}_0 = \operatorname{diag}(2, 1)$，简单特征值 $\lambda_0 = 2$，$\boldsymbol{v}_0 = \boldsymbol{e}_1$。沿 $\boldsymbol{E}_1 = \boldsymbol{e}_1\boldsymbol{e}_1^{\top}$，$\boldsymbol{S}_0 + t\boldsymbol{E}_1 = \operatorname{diag}(2 + t, 1)$，特征值为 $2 + t$，变化率为 $1 = \boldsymbol{e}_1^{\top}\boldsymbol{E}_1\boldsymbol{e}_1$，余项为零。

沿 $\boldsymbol{E}_2 = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$，公式给出 $\mathrm{d}\lambda(\boldsymbol{E}_2) = \boldsymbol{e}_1^{\top}\boldsymbol{E}_2\boldsymbol{e}_1 = 0$。直接计算，$\begin{bmatrix} 2 & t \\ t & 1 \end{bmatrix}$ 的较大特征值为 $\left(3 + \sqrt{1 + 4t^2}\right)/2 = 2 + t^2 + O(t^4)$，变化确实是二阶的。两个方向的谱范数都是 1，Weyl 界对两者都只给出 $|\lambda(t) - 2| \le |t|$。

例子显示了两类结论的分工。Weyl 界是对一切方向、任意步长都成立的最坏偏差；微分是指定方向上的变化率，它可以远小于最坏情形，甚至为零，但只在步长足够小时描述实际变化。用变化率预测有限扰动，还要知道余项多大，这正是最后一小节讨论的问题。

20.3.3 特征向量的微分

把它代回后，第一式右侧与 $\boldsymbol{v}_0$ 正交。由于 λ_0 简单，$\boldsymbol{S}_0 - \lambda_0\boldsymbol{I}$ 限制在 $\boldsymbol{v}_0$ 的正交补上可逆，因此第二式选出了唯一的 $\mathrm{d}\boldsymbol{v}(\boldsymbol{E})$。

谱展开与谱隙　在 $\boldsymbol{S}_0$ 的标准正交特征基中，向量响应可以显式写出。设 $\boldsymbol{S}_0\boldsymbol{v}_j = \lambda_j\boldsymbol{v}_j$（$j = 1, \dots, d$），$\boldsymbol{v}_1, \dots, \boldsymbol{v}_d$ 标准正交，并记 $\boldsymbol{v}_0 = \boldsymbol{v}_i$、$\lambda_0 = \lambda_i$。$\mathrm{d}\boldsymbol{v}(\boldsymbol{E})$ 与 $\boldsymbol{v}_i$ 正交，可写成 $\sum_{j \ne i} c_j\boldsymbol{v}_j$。代入第一式，左侧为 $\sum_{j \ne i} c_j(\lambda_j - \lambda_i)\boldsymbol{v}_j$；与 $\boldsymbol{v}_j$（$j \ne i$）作内积，右侧给出 $-\boldsymbol{v}_j^{\top}\boldsymbol{E}\boldsymbol{v}_i$，所以

$$\mathrm{d}\boldsymbol{v}(\boldsymbol{E}) = \sum_{j \ne i} \frac{\boldsymbol{v}_j^{\top}\boldsymbol{E}\boldsymbol{v}_i}{\lambda_i - \lambda_j}\,\boldsymbol{v}_j.$$

设 $d \ge 2$，令谱隙 $\gamma = \min_{j \ne i} |\lambda_i - \lambda_j|$，它因特征值简单而为正。由标准正交展开的 Parseval 等式，

$$\|\mathrm{d}\boldsymbol{v}(\boldsymbol{E})\|_2^2 = \sum_{j \ne i} \frac{(\boldsymbol{v}_j^{\top}\boldsymbol{E}\boldsymbol{v}_i)^2}{(\lambda_i - \lambda_j)^2} \le \frac{1}{\gamma^2}\sum_{j} (\boldsymbol{v}_j^{\top}\boldsymbol{E}\boldsymbol{v}_i)^2 = \frac{\|\boldsymbol{E}\boldsymbol{v}_i\|_2^2}{\gamma^2} \le \frac{\|\boldsymbol{E}\|_2^2}{\gamma^2},$$

即 $\|\mathrm{d}\boldsymbol{v}(\boldsymbol{E})\|_2 \le \|\boldsymbol{E}\|_2/\gamma$。$d = 1$ 时单位特征向量分支恒为 $\boldsymbol{v}_0$，微分为零。

特征值的导数界 $|\mathrm{d}\lambda(\boldsymbol{E})| \le \|\boldsymbol{E}\|_2$ 与这里的特征向量导数界可以一起与第 7.2节比较。Weyl 界与谱隙界控制的是有限扰动下特征值和特征子空间的整体变化；这里给出的是带方向的一阶响应。特征值的响应 $\boldsymbol{v}_i^{\top}\boldsymbol{E}\boldsymbol{v}_i$ 只看

扰动在该特征方向上的读数；特征向量的响应以 $\lambda_i-\lambda_j$ 为分母，说明谱隙小时，扰动可以把特征向量大幅地转向相邻的特征方向。

示例 20.8　特征向量的转向与谱隙　延续示例 20.7，沿 $\boldsymbol{E}_2$，公式给出 $\mathrm{d}\boldsymbol{v}(\boldsymbol{E}_2)=\frac{\boldsymbol{e}_2^{\top}\boldsymbol{E}_2\boldsymbol{e}_1}{2-1}\boldsymbol{e}_2=\boldsymbol{e}_2$，即 $\boldsymbol{v}(t)\approx\boldsymbol{e}_1+t\boldsymbol{e}_2$。直接计算，较大特征值的特征向量与 $(1,(\lambda(t)-2)/t)^{\top}$ 同向，而 $(\lambda(t)-2)/t=t+O(t^3)$，与一阶预测一致。

把基点换成 $\boldsymbol{S}_0=\operatorname{diag}(1+\gamma,1)$（$\gamma>0$），同一方向的响应变为 $\mathrm{d}\boldsymbol{v}(\boldsymbol{E}_2)=\boldsymbol{e}_2/\gamma$：谱隙缩小为原来的几分之一，特征向量的转向速率就放大几倍。

微分给出的是指定方向上的转向速率，有限扰动下子空间之间的角度、投影距离和偏转界仍以第 7章为准：定理 7.23给出 $\sin\theta\le\|\boldsymbol{E}\|_2/\gamma$ 型的界，其中谱隙按该定理的规定在原矩阵与扰动后矩阵的相应特征值之间度量。导数界 $\|\boldsymbol{E}\|_2/\gamma$ 与这个有限界形式相同，说明谱隙同时控制无穷小转向和有限偏转。

20.3.4　一阶近似的适用条件

前两小节的公式只在简单特征值附近成立，而且只描述步长趋零时的行为。用它们预测有限扰动，需要扰动相对谱隙足够小。示例 20.8的第二个基点可以精确算出这一点。

对 $\boldsymbol{S}_0+t\boldsymbol{E}_2=\begin{bmatrix}1+\gamma & t\\ t & 1\end{bmatrix}$，较大特征值的特征向量与 $\boldsymbol{e}_1$ 的夹角 θ 满足 $\tan 2\theta=2t/\gamma$，一阶预测则是 $\theta\approx t/\gamma$。二者在 $|t|\ll\gamma$ 时一致。$|t|$ 与 γ 同阶时，实际角度明显小于预测，例如 $t=\gamma/2$ 时 $\theta=\pi/8\approx0.39$，预测为 0.5。固定 t 而令 $\gamma\to0$ 时，实际角度趋于 $\pi/4$，预测却趋于无穷。

特征值也有同样的现象。较大特征值为 $1+\gamma/2+\sqrt{\gamma^2/4+t^2}$，在 $|t|\ll\gamma$ 时约为 $1+\gamma+t^2/\gamma$；一阶项为零，二阶项的系数 $1/\gamma$ 随谱隙缩小而增大。所以一阶预测可靠的条件不是“扰动小”，而是“扰动相对谱隙小”。

上面的结论依赖所选特征值简单。重特征值使关于未知量的导数不可逆，因此不能直接沿用这个构造；但这只说明这条论证失效，并不断言每一条特征值分支都不可微，也不意味着矩阵多项式或可逆点处的求逆映射失去光滑性。

第 20.1.1节的 $\operatorname{diag}(t,-t)$ 说明，在重特征值处，排序后的特征值可以有有限条件数而不可微，未排序的分支却仍然光滑。研究重特征值附近时，应改为考察相应的特征子空间，而不是强行指定其中某一个特征向量；谱簇子空间的稳定性已在第 7.2.3节处理，这里不重复谱扰动界。

总之，本节只界定简单谱分支何时可微，以及微分公式何时可以用作一阶近似。重根附近的稳定性需要把相邻特征值合成隔离的特征簇，比较整个特征子空间；这部分直接使用第 7章的结论。

20.4 本章小结

本章用三个量回答输入扰动的影响。微分给出指定方向上的一阶响应 $\mathrm{d}F_{\boldsymbol{x}}(\boldsymbol{h})$；局部条件数是这些响应在全部允许方向上的最坏放大倍数，可微时等于微分在允许方向子空间上的算子范数；余项说明给定步长下线性预测还差多少。三者回答不同的问题：条件数只描述无穷小扰动，可以有限而映射不可微，也可以为零而有限变化不为零；余项界需要导数沿整条扰动线段的 Lipschitz 型控制，二阶导数的统一界是取得这一控制的充分办法。

显式矩阵运算与隐式谱分支遵循同一套步骤：确定输出类型与误差尺度，限定允许的扰动结构，检查整条线段留在定义域内，再由微分读出响应与条件数、由精确增量或二阶信息估计余项。

线性运算的余项为零；乘积、平方与二次型的余项是可以精确写出的高次项；求逆的余项由逆差恒等式或 Neumann 级数给出，界为 $\|\boldsymbol{A}^{-1}\|^{3}\|\boldsymbol{E}\|^{2}/(1-q)$，相对条件数是 $\kappa_{2}(\boldsymbol{A})$；行列式的绝对变化在奇异处也有二次余项控制，相对条件数只在可逆时有意义，行列式数值小并不意味着求逆病态；对数行列式在对称正定情形下可以借最小特征值明确保证整条线段正定，余项界随到奇异边界的余量缩小而放大。

谱分支没有显式公式，先由隐函数定理在简单特征值处得到可微分支。特征值的变化率是扰动在特征方向上的读数 $\boldsymbol{v}^{\top}\boldsymbol{E}\boldsymbol{v}$，特征向量的变化率以特征值之差为分母，谱隙越小，转向越快。一阶预测可靠的条件是扰动相对谱隙小，而不只是扰动小；重根附近应改为比较隔离的特征子空间。

与已有结论相比，第 7章的有限扰动界给出对一切方向、一切步长有效的稳定性保证，第 14章评价方程解与算法的误差；本章补充的是指定方向的响应以及线性预测在有限步长下的精度。使用时要保留定义域、扰动结构、谱隙与相对尺度这些条件，不能用基点处的导数代替整段上的检查。

第 21 章

区域积分

一元积分沿区间累计：把区间切成小段，每段的长度乘函数值再相加。许多总量却分布在平面或空间的一块区域上，例如薄板的质量、物体的体积、一个地区的平均降雨量。本章要回答：怎样的区域有确定的体积，怎样的函数可以在区域上累计；累计出的数怎样实际算出来；换坐标或让被积函数带参数时，哪些操作是合法的。

第一节仿照一元 Riemann 积分，用坐标盒从内外两侧逼近区域，得到 Jordan 区域和它的体积，再用分割和定义积分，并整理线性、保序与区域可加性。定义同时分割全部坐标，不便直接计算，所以第二节在连续性条件下把多维积分化为逐坐标的一元积分；上下限由区域的截面决定，换序时要重新描述区域。无界区域或无界函数则要先截断，不同的截断方式可能给出不同的结果。

第三节用坐标变换简化区域。参数空间中同样大小的小块，映到原空间后体积不同，Jacobian 行列式的绝对值给出这一局部倍数；变换还必须单次覆盖区域，奇异坐标点要先截去再取极限。第四节研究依赖参数的积分，说明在什么统一控制下可以对参数取极限、在积分号下求导，以及积分限随参数移动时怎样计入边界贡献。

本章使用第 17章的 Jacobian、链式法则与连续偏导数判据，第 3章闭有界集上连续函数的一致连续性，以及一元 Riemann 积分和微积分基本定理，可参考卷一第 7 章“一元函数的积分”。所建立的区域积分是后面路径积分、曲面积分和积分定理的共同基础。

21.1 区域积分的定义与性质

一块不均匀的金属薄片占据平面区域 D，在点 (x,y) 附近每单位面积的质量为 $\rho(x,y)$。把 D 切成许多小块，每块的质量约等于块内某一点的密度乘这块的面积。把各块的质量相加，就得到总质量的近似值；小块切得越细，近似越准确。空间物体的质量、带电体的总电荷也这样累计，只是面积换成体积，面密度换成体密度或电荷密度。这类问题中的被积函数都是多元

标量函数 $f : D \subseteq \mathbb{R}^d \to \mathbb{R}$。它的输入是一个位置的 d 个坐标，输出是该位置上待累计的一个数。

同一个积分还有两种常用读法。若 $f \geq 0$ 定义在平面区域 D 上，积分等于以 D 为底、以 f 的图像为顶的立体的体积。这是一元积分“曲线下方的面积”在高一维的对应。当 D 的面积有限且非零时，积分除以面积就是 f 在 D 上的平均值，例如一个地区的平均降雨量或一块薄板的平均温度。

本节把一元 Riemann 积分推广到有界区域上。先说明怎样的区域有确定的体积，再用分割和定义积分，最后整理积分的基本性质。一般可测函数与积分的极限定理在卷四中建立，本章不以它们为前提，可参考卷四第 4 章“积分”。

21.1.1 盒体积与 Jordan 可测性

一元积分把区间切成小区间，每个小区间的长度都已知。多元积分要把区域切成小块，首先需要知道小块的体积。最简单的小块是坐标盒。闭坐标盒 $Q = \prod_{j=1}^{d} [a_j, b_j]$ 的体积定义为

$$\operatorname{vol}(Q) = \prod_{j=1}^{d} (b_j - a_j).$$

某条边长度为零时，体积为零。

盒体积满足有限可加性。沿某个坐标把盒切成两块，被切的边长相加仍等于原边长，所以两块体积之和等于原体积。反复这样切，可知任意有限网格中小盒的体积之和都等于原盒体积。相邻小盒只共享边界，公共边界不重复贡献体积。

一般区域不是盒，它的体积用盒从内外两侧逼近。设 $D \subset \mathbb{R}^d$ 有界。取有限个内部互不相交、且都含于 D 的盒，它们的总体积从内侧估计 D 的体积；再取有限个内部互不相交、并合起来覆盖 D 的盒，它们的总体积从外侧估计。若对每个 $\varepsilon > 0$，都能选出这样的内侧盒组和外侧盒组，使两者总体积之差小于 ε，就称 D 为Jordan 可测集合，简称 Jordan 区域。

任何一组内侧盒的总体积都不超过任何一组外侧盒的总体积；两侧差距又可以任意小，所以夹在两侧之间的数只有一个。这个数称为 D 的 Jordan 体积，记为 $|D|$。它不依赖所选的盒组。

按定义检查内外逼近并不方便。下面的判别把问题归结为边界：有界集合 D 是 Jordan 可测的，当且仅当它的边界 ∂D 能被有限个总体积任意小的盒覆盖。

先证明充分性，关键是下面的观察。不在边界上的点，要么有一个邻域完全落在 D 内，要么有一个邻域完全落在 D 外。所以一个小盒若同时含有 D 的点和 D 外的点，它必与边界相交。

设边界可被总体积小于 $\varepsilon/2$ 的有限个盒覆盖。把这些盒的各边稍微向外扩张，使总体积仍小于 ε。盒的个数有限，所以可以在一个包含 D 的盒上取足够细的网格，使每个与边界相交的网格小盒都落入某个扩张盒。网格小盒内部互不重叠，因此与边界相交的小盒总体积小于 ε。

取含于 D 的网格小盒作内侧逼近，取与 D 相交的网格小盒作外侧逼近。两者之差只由同时接触 D 和 D 外的小盒组成，这些小盒都与边界相交，总体积小于 ε。所以 D 是 Jordan 可测的。

反过来，设 D 是 Jordan 可测的。边界上的点不在内侧盒组的内部，却在外侧盒组之中，所以边界含于“外侧盒组减去内侧盒组内部”所剩的部分。这部分的体积不超过两侧总体积之差，另外至多含有有限个盒的边界。盒的边界同样可以用总体积任意小的有限个盒覆盖，所以整个边界也可以。

这一判别也说明边界为何不影响累计。只要被积函数有界，落在边界附近的小块的总贡献，就不超过函数绝对值的上界乘覆盖盒的总体积，可以任意小。

例如闭圆盘是 Jordan 可测的。把圆周分成有限条足够短的弧，每条弧用一个小正方形覆盖。弧长尺度缩小时，所需正方形的个数按尺度的倒数增长，每个正方形的面积按尺度的平方缩小，所以总面积趋于零。同样，有限条分段光滑曲线围成的平面区域，以及有限片光滑曲面围成的有界立体，其边界都能这样覆盖。这里依赖于边界只有有限片，且每片有足够规则的参数化；不能仅凭边界“看起来像曲线或曲面”就忽略它。

21.1.2　多元 Riemann 和与可积性

有了 Jordan 区域，就可以仿照一元情形定义积分。先在坐标盒上定义，再推广到一般区域。

设 R 是包含 D 的闭坐标盒。沿各坐标作有限分割，得到小盒 $Q_1, \dots, Q_N$，各小盒直径的最大值称为网格大小。在每个 Q_i 中任选取样点 $\boldsymbol{\xi}_i$，对 R 上的有界函数 g 作 Riemann 和

$$S(g, P, \boldsymbol{\xi}) = \sum_{i=1}^{N} g(\boldsymbol{\xi}_i)\,\mathrm{vol}(Q_i).$$

若网格大小趋于零时，无论怎样选取分割和取样点，这些和都趋于同一个有限值，就称 g 在 R 上 Riemann 可积，这个极限记作 $\int_R g(\boldsymbol{x})\,\mathrm{d}\boldsymbol{x}$。这一要求针对所有足够细的分割和所有取样方式，而不只是某一种选点方式。

逐一检查所有取样方式并不可行，常用上和与下和来判断。在每个小盒上分别取 g 的上确界和下确界，乘盒体积再求和，得到上和 $U(g,P)$ 与下和 $L(g,P)$。任意取样所得的 Riemann 和都夹在二者之间。因此，g 可积当且仅当分割足够细时 $U(g,P)-L(g,P)$ 可以任意小。

连续函数满足这一条件。若 g 在 R 上连续，由于 R 是紧集，g 一致连续。网格足够细时，每个小盒上函数的最大值与最小值相差任意小；上和与下和之差不超过这个差值乘 R 的体积，因而任意小。所以 g 可积。

一般区域上的积分通过零延拓化为盒上的积分。设 D 是有界 Jordan 区域，f 是 D 上的有界函数。令 $g=f\mathbb{1}_D$，即 g 在 D 上等于 f，在 $R\setminus D$ 上取零。若 g 在 R 上 Riemann 可积，就把它的积分定义为 $\int_D f$。换一个更大的包含盒，只是多了一片取零的区域，积分不变。

若 f 能连续延拓到闭包 $\overline{D}$，则零延拓可积。延拓后的函数在闭包上一致连续，所以远离边界的小盒上，函数的振幅可以任意小；靠近边界的小盒，由前面的边界覆盖控制总体积。两部分对上下和之差的贡献都可以任意小。同样的论证适用于分块连续的有界函数：区域分成有限块，函数在每块上连续，不连续点只落在各块的边界上。函数在这些边界上怎样取值，不影响积分。

连续是可积的充分条件，但不是必要条件。例如在 $R=[0,1]^2$ 上令 $g(x,y)=\mathbb{1}_{\{x\ge 1/2\}}$。它在直线 $x=1/2$ 上不连续，但只有穿过这条直线的网格小盒会让上和与下和不同。这些小盒的总面积随网格变细而趋于零，所以 g 可积，积分为 $1/2$。

另一方面，函数有界并不足以保证可积。$\mathbb{1}_{\mathbb{Q}^2}$ 在每个非退化小盒内既取 0 也取 1，上和与下和之差始终等于 R 的面积，所以它不可积。

21.1.3 积分的基本性质

区域积分的基本性质都由有限 Riemann 和的相应性质取极限得到。积分是线性的。积分保持大小关系：若 f、h 可积且 $f\le h$，则

$$\int_D f \le \int_D h.$$

积分还满足绝对值估计 $\left|\int_D f\right|\le \int_D |f|$。若有限个 Jordan 区域内部互不重叠，只沿可忽略的公共边界拼接，则在拼成的区域上的积分等于各块上的积分之和，这就是区域可加性。

常见的累计量都可以写成区域积分。取 $f=1$ 得到体积 $|D|$；非负密度 ρ 的积分是总质量 $M=\int_D \rho$。当 $|D|>0$ 时，f 的平均值为

$$\frac{1}{|D|}\int_D f.$$

当 M 有限且非零时，质心为

$$\frac{1}{M}\int_D \boldsymbol{x}\,\rho(\boldsymbol{x})\,\mathrm{d}\boldsymbol{x},$$

其中向量值函数的积分按分量计算。

21.2　累次积分

区域积分的定义同时分割所有坐标。实际计算时，我们希望先沿一个坐标方向积分，再沿其余方向积分，把一次 d 维累计化为几次一元积分。本节说明这在什么条件下成立，以及上下限怎样由区域的截面确定。

21.2.1　长方体上的累次积分

先看矩形。设 f 在闭矩形 $R=[a,b]\times[c,d]$ 上连续。固定 x 时，$y\mapsto f(x,y)$ 连续，所以一元积分

$$F(x)=\int_c^d f(x,y)\,\mathrm{d}y$$

存在。f 在 R 上一致连续，所以 x 的变化足够小时，所有 $y\in[c,d]$ 处的函数值同时变化很小，F 因而连续。

取乘积网格，把 Riemann 和中的项按列分组。每一列的内层求和趋于该列上 y 方向的积分，一致连续性保证所有列的误差同时很小；外层求和再趋于 $\int_a^b F(x)\,\mathrm{d}x$。按行分组同理，于是

$$\int_R f(x,y)\,\mathrm{d}(x,y)=\int_a^b\left(\int_c^d f(x,y)\,\mathrm{d}y\right)\mathrm{d}x=\int_c^d\left(\int_a^b f(x,y)\,\mathrm{d}x\right)\mathrm{d}y.$$

更多坐标的闭盒可以重复这样分组。

连续性是便于核对的充分条件。对一般的 Riemann 可积函数，某些截面上的一元积分可能不存在，所以不能只因整体可积就省去对内层积分的检查。

21.2.2　简单区域上的累次积分

一般区域上，累次积分的上下限由截面决定。设

$$D=\{(x,y)\,:\,a\le x\le b,\ \alpha(x)\le y\le \beta(x)\},$$

其中边界函数 $\alpha\le\beta$ 连续，且 f 在 D 的闭包上连续，则

$$\int_D f(x,y)\,\mathrm{d}(x,y)=\int_a^b\left(\int_{\alpha(x)}^{\beta(x)} f(x,y)\,\mathrm{d}y\right)\mathrm{d}x.$$

这同样是对零延拓的网格分组。边界曲线附近的格子总体积可以任意小，其余格子按截面累计。边界函数连续，在紧区间上一致连续，所以截面的端点随 x 一致变化，内层积分也随 x 连续。由有限个这样的区域拼成的区域可以逐块计算，公共边界不重复累计。

换一种积分次序时，要重新求出区域在另一坐标轴上的投影和相应的截面。例如取 $D=\{0\le y\le x\le 1\}$ 和 $f(x,y)=x+y$。固定 x，截面为 $0\le y\le x$，得到

$$\int_0^1\left(\int_0^x (x+y)\,\mathrm{d}y\right)\mathrm{d}x=\int_0^1 \frac{3x^2}{2}\,\mathrm{d}x=\frac{1}{2}.$$

固定 y，截面变为 $y\le x\le 1$，同一个积分也等于

$$\int_0^1\left(\int_y^1 (x+y)\,\mathrm{d}x\right)\mathrm{d}y=\int_0^1\left(\frac{1}{2}+y-\frac{3y^2}{2}\right)\mathrm{d}y=\frac{1}{2}.$$

两组上下限描述的是同一个三角形的两种截面，而不是把积分号机械地交换。

换序还可能改变分块方式。区域 $0\le x\le 2$、$0\le y\le \min(x,2-x)$ 是一个三角形。先对 y 积分时，上限在 $x=1$ 处改变公式，需要分成两块；先对 x 积分时，截面是 $y\le x\le 2-y$，y 取遍 $[0,1]$，一块即可。取 $f=1$ 核对，两种次序都给出面积 1。

21.2.3 反常重积分与积分次序

前面的结论只针对有界区域上的有界函数。区域无界，或被积函数在某点附近无界时，Riemann 和不能直接使用。常用的做法是截断：选一族有界 Jordan 区域 D_ε，它们避开奇点或截去远处，先逐个检查 f 在每个 D_ε 上 Riemann 可积，再考察 $\int_{D_\varepsilon} f$ 的极限。需要注意，沿某一族截断得到的极限，不能说明其他截断方式会给出同一结果。

例如在 $(0,1]^2$ 上取

$$f(x,y)=\frac{x^2-y^2}{(x^2+y^2)^2}.$$

对 $0<\varepsilon<1$，先用矩形 $D_\varepsilon=[\varepsilon,1]\times[\varepsilon^2,1]$ 截断。每个截断矩形都远离原点，f 在其上连续。

先把下边界暂时放宽到 $y=0$。对固定的 $x>0$，$y\mapsto f(x,y)$ 在 $[0,1]$ 上连续，原函数为 $y/(x^2+y^2)$，所以

$$\int_\varepsilon^1\left(\int_0^1 f(x,y)\,\mathrm{d}y\right)\mathrm{d}x=\int_\varepsilon^1 \frac{\mathrm{d}x}{1+x^2}\longrightarrow\frac{\pi}{4}.$$

放宽时多算的窄条是 $[\varepsilon,1]\times[0,\varepsilon^2]$。由 $|x^2-y^2|\le x^2+y^2$，窄条上 $|f(x,y)|\le 1/x^2$，所以它的贡献不超过

$$\varepsilon^2\int_{\varepsilon}^{1} x^{-2}\,\mathrm{d}x \longrightarrow 0.$$

因此 $\int_{D_\varepsilon} f\to\pi/4$。

交换两条边的截断速度，改用 $E_\varepsilon=[\varepsilon^2,1]\times[\varepsilon,1]$。由 $f(y,x)=-f(x,y)$，所得极限是 $-\pi/4$。两族矩形都逐渐填满同一个区域 $(0,1]^2$，极限却不同，所以这里没有与截断方式无关的总量。同样的计算也说明累次积分不能随意换序：$\int_0^1\bigl(\int_0^1 f\,\mathrm{d}y\bigr)\mathrm{d}x=\pi/4$，而先对 x 积分的累次积分等于 $-\pi/4$。

21.3　区域积分的换元

圆盘用半径和角度描述，比用两个直角坐标简单。但换坐标不只是替换函数中的变量：参数空间中大小相同的小块，映到原空间后体积可能不同。线性映射把体积乘以其行列式的绝对值；可微映射在足够小的范围内近似线性。换元公式就是把这些局部的体积比例累计起来。

21.3.1　积分换元公式

为了保证每个点只被计算一次，并便于处理边界，先在两个开集之间取一个可微双射，再在其中选取有界的积分区域。

定理 21.1　经典区域积分的换元　设 $U,V\subseteq\mathbb{R}^d$ 为开集，$T:U\to V$ 为 C^1 双射，逆映射也为 C^1。设 $E\subset U$ 为紧 Jordan 区域，且 $T(E)$ 也是 Jordan 区域。若 f 在 $T(E)$ 上连续，则

$$\int_{T(E)} f(\boldsymbol{x})\,\mathrm{d}\boldsymbol{x}=\int_{E} f(T(\boldsymbol{u}))\,|\det DT(\boldsymbol{u})|\,\mathrm{d}\boldsymbol{u}.$$

下面说明权重 $|\det DT|$ 的来源，并概述证明的思路。取 E 附近的等边网格。对其中的小立方体，连续可微性给出一阶近似

$$T(\boldsymbol{u}+\boldsymbol{h})-T(\boldsymbol{u})=DT(\boldsymbol{u})\boldsymbol{h}+\boldsymbol{R}_{\boldsymbol{u}}(\boldsymbol{h}).$$

当 $\|\boldsymbol{h}\|\le\delta$ 时，余项满足 $\|\boldsymbol{R}_{\boldsymbol{u}}(\boldsymbol{h})\|\le\eta(\delta)\|\boldsymbol{h}\|$，其中 $\eta(\delta)\to 0$，而且这个界在紧集上对 $\boldsymbol{u}$ 一致成立。逆映射的导数同样有界，所以小立方体的像不会在某个方向上被任意压扁。

线性部分 $DT(\boldsymbol{u})$ 把小立方体映成一个平行多面体，体积是原体积乘 $|\det DT(\boldsymbol{u})|$。在这个平行多面体的边界外加一层厚度与 $\eta(\delta)\delta$ 同阶的薄层，

就能夹住小立方体的真实像。薄层体积与原立方体体积之比趋于零，所以局部体积比趋于 $|\det DT(\boldsymbol{u})|$。

再把像区域上的 Riemann 和与参数区域上的加权 Riemann 和逐项比较。函数值替换的误差由 f 的一致连续性控制，体积替换的误差由上面一致的余项界控制，边界附近的小块由 Jordan 条件控制。令网格变细，就得到换元公式。这里只给出了证明的思路。只写出某一点处的线性近似还不够，要交换整个分割和的极限，必须用到上面一致的误差控制。

定理中的全局双射条件不能省略。逆函数定理只保证每一点附近可以反解，并不保证整个区域只被覆盖一次；覆盖两次，积分就会累计两次。行列式取绝对值，消去的是定向的符号，不能消去覆盖次数。

21.3.2 极坐标、柱坐标与球坐标

平面极坐标把 (r,θ) 映为 $(r\cos\theta, r\sin\theta)$，Jacobian 行列式为 r。同样的角度宽度，在半径较大处扫过更长的弧，所以参数矩形的面积不等于平面小块的面积。面积权重为

$$\mathrm{d}A = r\,\mathrm{d}r\,\mathrm{d}\theta.$$

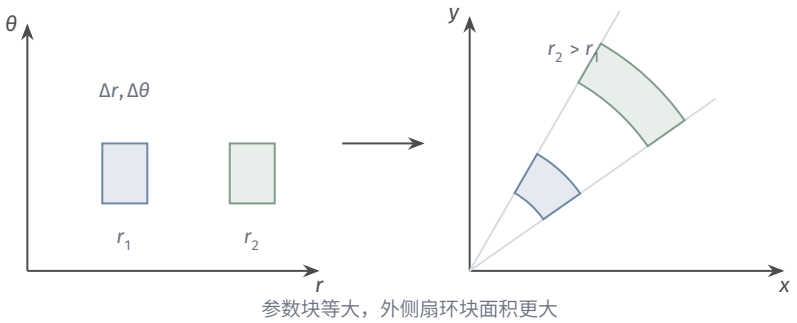


图 21.1　径向宽度和角度宽度相同时，半径越大，对应的面积越大。小块的一阶面积为 $r\Delta r\Delta\theta$，由此得到极坐标的面积权重。

极坐标在闭参数矩形上不满足换元定理的条件：原点处行列式为零，角度的两端又表示同一条射线。处理办法是先截断。限制 $r \ge \varepsilon$ 且 $\varepsilon \le \theta \le 2\pi - \varepsilon$，在这个紧区域上应用换元定理，再令 $\varepsilon \downarrow 0$。对于圆盘上的连续函数，去掉的小圆盘和窄扇形的贡献不超过函数的上界乘它们的面积，趋于零；参数一侧遗漏的部分也由有界的权重控制。

例如半径为 R 的圆盘面积为

$$\int_0^{2\pi}\int_0^{R} r\,\mathrm{d}r\,\mathrm{d}\theta = \pi R^2.$$

若角度取到 4π，圆盘内部被覆盖两次，结果也变成两倍。被积函数有奇点时，不能只说“接缝不贡献面积”而跳过截断的极限估计。

柱坐标在极坐标之外保留高度 z，体积权重仍含因子 r：

$$\mathrm{d}V = r\,\mathrm{d}r\,\mathrm{d}\theta\,\mathrm{d}z.$$

由此，半径为 R、高为 H 的圆柱体积为 $\pi R^2 H$。轴线和角度接缝的处理与极坐标相同。

球坐标使用到原点的距离 ρ、从正 z 轴量起的极角 φ 和方位角 θ：

$$T(\rho,\varphi,\theta) = (\rho\sin\varphi\cos\theta,\ \rho\sin\varphi\sin\theta,\ \rho\cos\varphi).$$

三个参数各自变化时，点沿三个相互正交的方向移动，长度的放大比例分别是 1、ρ 和 $\rho\sin\varphi$。三者相乘就是体积权重，直接计算 Jacobian 行列式也得到同一结果：

$$\mathrm{d}V = \rho^2\sin\varphi\,\mathrm{d}\rho\,\mathrm{d}\varphi\,\mathrm{d}\theta.$$

在 $\rho>0$、$0<\varphi<\pi$ 和一个长度为 2π 的开角度区间上，这个映射是双射，像是空间去掉 z 轴和一个接缝半平面后的部分。计算球内连续函数的积分时，先截去原点、极轴和接缝附近的小区域，再用函数的有界性估计遗漏的部分。由此得到球的体积

$$\int_0^{2\pi}\int_0^{\pi}\int_0^{R}\rho^2\sin\varphi\,\mathrm{d}\rho\,\mathrm{d}\varphi\,\mathrm{d}\theta = \frac{4\pi R^3}{3}.$$

21.3.3　线性换元

线性换元可以把斜着放的区域变成坐标盒。设 D 由 $0\le x+y\le 2$ 和 $0\le x-y\le 2$ 围成，求 $\iint_D (x+y)\,\mathrm{d}(x,y)$。令 $u=x+y$、$v=x-y$，参数区域就是 $[0,2]^2$，逆变换为

$$x=\frac{u+v}{2},\qquad y=\frac{u-v}{2}.$$

逆变换的 Jacobian 行列式为 $-1/2$，所以面积权重为 $1/2$。于是

$$\iint_D (x+y)\,\mathrm{d}(x,y) = \int_0^2\int_0^2 \frac{u}{2}\,\mathrm{d}u\,\mathrm{d}v = 2.$$

这个结果可以用另外两个量核对。取被积函数为 1，同样的换元给出区域面积 2。$x+y=u$ 在区域上的平均值为 1，平均值乘面积也是 2。区域、权重和积分值由此得到同时检验。

21.4 参数积分

若被积函数还依赖一个参数，积分值就随参数变化，成为参数的函数。例如一块薄板的密度随时间改变，总质量就是时间的函数。判断这个函数是否连续、能否求导，需要控制整个积分区域上的变化；只在每一点处成立的极限不够。本节固定紧 Jordan 区域 D，用连续性提供这种统一的控制。

21.4.1 参数积分的连续性

设 K 为紧参数区域，f 在 $D\times K$ 上连续，记

$$F(\boldsymbol{t})=\int_D f(\boldsymbol{x},\boldsymbol{t})\,\mathrm{d}\boldsymbol{x}.$$

$D\times K$ 是紧集，f 在其上一致连续，所以 $\boldsymbol{t}\to\boldsymbol{s}$ 时，

$$\sup_{\boldsymbol{x}\in D}|f(\boldsymbol{x},\boldsymbol{t})-f(\boldsymbol{x},\boldsymbol{s})|\longrightarrow 0.$$

用绝对值估计，

$$|F(\boldsymbol{t})-F(\boldsymbol{s})|\le |D|\sup_{\boldsymbol{x}\in D}|f(\boldsymbol{x},\boldsymbol{t})-f(\boldsymbol{x},\boldsymbol{s})|\longrightarrow 0,$$

所以 F 连续。参数区域不必整体有界。讨论某个内点附近的连续性时，取包含该点的一个小闭盒作为 K 即可。

21.4.2 积分号下求导

求导的思路相同：把参数差商的极限放进积分号内，关键是证明差商对所有 $\boldsymbol{x}\in D$ 一致收敛。

设参数取自开集，f 和各参数偏导数 $\partial_{t_j}f$ 在 D 与参数邻域的乘积上连续。固定一个参数点，取它的一个足够小的闭邻域。由一元中值定理，沿 t_j 方向的差商等于附近某个参数处的偏导数值。偏导数在紧集上一致连续，所以差商对全部 $\boldsymbol{x}\in D$ 一致趋于 $\partial_{t_j}f$。对差商与偏导数之差积分，并用上一小节的上确界估计，得到

$$\partial_{t_j}F(\boldsymbol{t})=\int_D \partial_{t_j}f(\boldsymbol{x},\boldsymbol{t})\,\mathrm{d}\boldsymbol{x}. \tag{21.1}$$

右侧又是一个被积函数连续的参数积分，由上一小节，它是参数的连续函数。于是 F 的各个偏导数都存在且连续，由连续偏导数判据，F 是 C^1 函数，全微分为

$$DF_{\boldsymbol{t}}[\boldsymbol{h}]=\int_D D_{\boldsymbol{t}}f(\boldsymbol{x},\boldsymbol{t})[\boldsymbol{h}]\,\mathrm{d}\boldsymbol{x}.$$

整体可微是由连续偏导数推出的；只验证每个方向上的极限，还不能得到这一结论。

例如 $F(t)=\int_0^1 e^{tx}\,\mathrm{d}x$ 在任意有界参数区间上都满足上述条件，所以

$$F'(0)=\int_0^1 x\,\mathrm{d}x=\frac{1}{2}.$$

显式表达式 $F(t)=(e^t-1)/t$ 在 $t=0$ 处有可去奇点；在积分号下求导，就不必处理它。

21.4.3 变限参数积分

积分区间也随参数变化时，积分值的变化来自两部分：区间内部的被积函数在变，两端又新添或移除了细条。

设 $a(t),b(t)$ 为 C^1 函数，$f(x,t)$ 及 $\partial_t f(x,t)$ 在所需区间附近连续。把积分写成从某个固定点到 $b(t)$ 的积分减去从该点到 $a(t)$ 的积分，对上限用一元基本定理，对被积函数中的参数用式 (21.1)，再由链式法则合并，得到

$$\frac{\mathrm{d}}{\mathrm{d}t}\int_{a(t)}^{b(t)} f(x,t)\,\mathrm{d}x=\int_{a(t)}^{b(t)}\partial_t f(x,t)\,\mathrm{d}x+f(b(t),t)b'(t)-f(a(t),t)a'(t).$$

第一项来自被积函数的变化，后两项来自端点的移动。上端向右移动会增加积分，下端向右移动会减少积分，所以两个边界项符号相反。

有多个参数时，对每个参数分别求偏导；也可以把 a'、b' 和 $\partial_t f$ 换成作用于同一参数增量的全微分。更一般的移动区域会产生沿整个边界的贡献，本章只在上述区间变限的情形使用这一规则。

21.5 本章小结

区域积分把密度累计成总量。Jordan 区域是能用有限个坐标盒从内外两侧任意逼近的有界集合，等价地，它的边界能被总体积任意小的有限个盒覆盖。边界因而不影响有界函数的累计：在区域闭包上连续的函数可积，分块连续的有界函数也可积；有界本身则不够，例如有理点的指示函数不可积。积分继承有限和的线性、保序、绝对值估计与区域可加性，体积、质量、平均值和质心都是区域积分。

累次积分把一次多维累计化为几次一元积分。被积函数连续、区域由连续的边界函数描述时，按截面分组的 Riemann 和收敛到累次积分，两种次序给出同一个值；换序时要重新求出区域在另一坐标轴上的投影和截面，必要时改变分块。区域无界或被积函数无界时，有界情形的结论不能直接使用：要先截断再取极限，而不同的截断方式和不同的积分次序可以给出不同的结果。

换元时，可微映射在一点附近近似线性，Jacobian 行列式的绝对值给出局部体积的缩放，换元公式把这些倍数累计起来。公式要求两个开集之间的 C^1 双射及 C^1 逆，绝对值消去的是定向的符号，消不去覆盖次数。极坐标、柱坐标和球坐标的权重分别为 r、r 与 $\rho^2 \sin\varphi$；它们在原点、轴线和角度接缝处不满足条件，须先截去这些部分，再用被积函数的有界性控制遗漏的贡献。

参数积分在紧 Jordan 区域上依赖统一控制：被积函数在区域与参数集的乘积上连续时，积分随参数连续；参数偏导数也联合连续时，可以在积分号下求导，并由连续偏导数推出全微分。只有逐点的极限不够。积分限随参数移动时，导数除了积分号下的项，还要加上两端新增或移除的细条贡献。下一章把累计的范围从区域换成曲线。

第 22 章

路径积分

区域积分累计铺满一块区域的量。许多问题却只沿一条曲线累计。一根弯曲细铁丝的质量，由各处的线密度和铁丝的长度决定。把物体沿一条路线推过去，推力做的功不仅取决于力的大小和路线的长度，还取决于力与前进方向的夹角。

两类问题都沿曲线累计，被积对象却不同：线密度在每一点给出一个数，是标量场；力在每一点给出一个带方向的量，是向量场（第 17.1节）。本章要回答：怎样沿曲线按长度累计一个标量场，怎样沿行进方向累计一个向量场的作用，以及后一种累计什么时候只取决于起点和终点。

相应地有两种路径积分。第一类路径积分把曲线切成小段，用每段上的函数值乘这段的长度再相加，铁丝的质量就这样算出，它与沿哪个方向走过曲线无关。第二类路径积分在每一小段上取力与这段有向位移的内积，只保留力沿前进方向的分量，再把这些数相加。反向行走时每段位移都反号，积分也随之变号。

第一节用参数路径描述一次行进，区分曲线的像、参数的快慢、行进方向与重复覆盖，并用速度长度的积分计算弧长。第二节在此基础上按弧长累计标量场；第三节改为累计向量场的切向分量，方向随之进入结果。第四节研究功只依赖端点的情形，这对应物理中保守力与势能的关系：势函数把沿途累计化为端点差，交叉偏导相等给出可以检查的微分条件，而定义域中的洞会使这一条件失效。

本章的参数积分都是一元 Riemann 积分；路径无关的判别要用到第 17章的链式法则、混合偏导数的交换，以及第 21章的积分号下求导。经典构造可参考[1]。

[1] G. Strang, E. J. Herman, *Calculus Volume 3*, OpenStax, 2016

22.1 参数路径与弧长

描述一次行进，需要知道每个时刻所在的位置。位置随时间连续变化，就得到一条路径；位置对时间的导数是速度，速度的大小称为速率。速率恒

定时，速率乘经过的时间就是走过的路程；速率随时间变化时，路程是速率对时间的积分。

22.1.1 路径的定义

参数化路径 不妨把参数 t 看成时间，把 $\gamma(t)$ 看成一个质点在时刻 t 所在的位置。经过同一组位置时，可以走得快或慢，可以从任一端出发，也可以来回走好几遍。只记下经过了哪些点，就会丢失这些信息。用区间到空间的连续映射描述行进，位置和先后次序就一起保留下来。

> **定义 22.1 路径** 设 $a<b$。连续映射 $\gamma:[a,b]\to\mathbb{R}^d$ 称为一条**路径**（path），$\gamma(a)$ 和 $\gamma(b)$ 分别为起点和终点；若两者相等，称为闭路径。集合 $C=\gamma([a,b])$ 称为路径的像。

像集 C 只记录质点经过的位置，参数 t 还规定了经过的先后次序，所以同一个像集可以对应行进方式完全不同的路径。

> **示例 22.2 同一条对角线段上的三条路径** 以下三条平面路径的像都是连接 $(0,0)$ 与 $(1,1)$ 的对角线段：
>
> - $\gamma(t)=(t,t)^{\mathsf T}$，$0\le t\le 1$，从 $(0,0)$ 走到 $(1,1)$，速度为 $(1,1)^{\mathsf T}$；
> - $\eta(u)=(u/2,u/2)^{\mathsf T}$，$0\le u\le 2$，同样从 $(0,0)$ 走到 $(1,1)$，速度减半为 $(1/2,1/2)^{\mathsf T}$，用时加倍；
> - $\rho(t)=(t,t)^{\mathsf T}$（$0\le t\le 1$）、$\rho(t)=(2-t,2-t)^{\mathsf T}$（$1\le t\le 2$），先走到 $(1,1)$ 再原路返回。
>
> γ 与 η 只是快慢不同，线段上每个点都恰好经过一次。ρ 的像仍是这条线段，但每个内点被经过两次：去程一次，回程一次。

后面会看到，两种路径积分对 γ 与 η 给出相同的结果。沿 ρ 按长度累计时，结果是沿 γ 的两倍；按有向位移累计时，去程与回程恰好抵消。所以路径积分是沿一次行进定义的，只知道像集还不能确定它。计算一根铁丝的质量时，应选一条把铁丝恰好走一遍的路径。

分段光滑路径 示例 22.2中的往返路径 ρ 在 $t=1$ 处突然掉头，正方形的边界在四个角处突然转向。这些位置没有唯一的切线方向，但在每一段直线上，速度都存在且连续。为了把折线、多边形边界这类常见路径纳入计算，允许路径在有限个参数点处分段。

定义 22.3 分段光滑路径 若存在分割 $a = t_0 < t_1 < \cdots < t_n = b$，使 γ 在每个 $[t_{j-1}, t_j]$ 上为 C^1 映射，称 γ 为分段 C^1 路径，也称分段光滑路径。若每段内部还满足 $\gamma'(t) \neq \mathbf{0}$，称该路径分段正则。

这里“在闭区间 $[t_{j-1}, t_j]$ 上为 C^1”是指该段内部的导数连续，并能连续延拓到该段的两个端点；相邻两段在公共端点处的导数不必相同。例如 ρ 在 $[0,1]$ 上的速度为 $(1,1)^{\top}$，在 $[1,2]$ 上的速度为 $(-1,-1)^{\top}$。两段在 $t=1$ 处的速度不同，但各自连续，所以 ρ 是分段 C^1 路径。

本章的路径积分都在分段 C^1 路径上定义。折点只有有限个，改变有界函数在有限个点上的取值不影响 Riemann 积分，所以折点处的速度怎样取值都不影响参数积分。分段正则要求每段内部速度不为零，排除了质点中途停住的情形。本章的积分不要求路径正则；后面用到单位切向量时，只在速度非零处使用它。

22.1.2 路径的长度

弧长 测量一条弯曲道路的长度时，可以在路上依次插几根标杆，量出相邻标杆之间的直线距离再相加。每段直线距离都不超过对应那段路的实际长度，所以折线长度不会超过道路长度。在两根标杆之间再插一根，由三角不等式，新折线不会变短。标杆越密，折线越贴近道路，因此把道路的长度定义为所有内接折线长度的上确界。

定义 22.4 路径的弧长 路径 $\gamma : [a,b] \to \mathbb{R}^d$ 的弧长定义为

$$\ell(\gamma) = \sup_{a=t_0<\cdots<t_n=b} \sum_{j=1}^{n} \|\gamma(t_j) - \gamma(t_{j-1})\|_2 .$$

上确界取遍 $[a,b]$ 的全部有限分割；若此值有限，称路径可求长。

这个定义只用到路径上点的位置，不需要导数，所以任何连续路径都可以讨论它是否可求长。

对分段光滑路径，弧长可以用速度直接计算。在一小段参数区间 $[t_{j-1}, t_j]$ 上，质点的位移近似为速度乘时间：

$$\gamma(t_j) - \gamma(t_{j-1}) \approx \gamma'(t_{j-1})(t_j - t_{j-1}).$$

所以这一小段的长度近似为速率 $\|\gamma'(t_{j-1})\|_2$ 乘时间，汽车里程表就是这样累计路程的。把这些乘积相加，再令分割变细，就得到下面的公式。

定理 22.5　分段光滑路径的弧长　若 $\gamma:[a,b]\to\mathbb{R}^d$ 分段 C^1，则它可求长，且

$$\ell(\gamma)=\int_a^b \|\gamma'(t)\|_2\,\mathrm{d}t.$$

证明　加入分点不会使折线变短，所以计算上确界时只需考虑包含全部折点的分割；这样的折线长度按光滑段相加，弧长也按段相加。因此只需在一段 C^1 区间上证明，再把各段的等式相加。证明分两步：先说明任何折线都不比速度积分长，再说明足够细的折线与速度积分相差任意小。

第一步。对该段中的 $\alpha<\beta$，由各坐标分量的一元基本定理，$\gamma(\beta)-\gamma(\alpha)=\int_\alpha^\beta\gamma'(t)\,\mathrm{d}t$，这里向量的积分表示对各分量分别积分。若弦 $\gamma(\beta)-\gamma(\alpha)$ 非零，取它方向上的单位向量 $\boldsymbol{u}$，则由 Cauchy–Schwarz 不等式

$$\|\gamma(\beta)-\gamma(\alpha)\|_2=\boldsymbol{u}^{\top}\big(\gamma(\beta)-\gamma(\alpha)\big)=\int_\alpha^\beta \boldsymbol{u}^{\top}\gamma'(t)\,\mathrm{d}t\le\int_\alpha^\beta\|\gamma'(t)\|_2\,\mathrm{d}t;$$

弦为零时这个不等式直接成立。同样的推理说明，任何连续向量值函数 $\boldsymbol{v}$ 都满足 $\|\int_\alpha^\beta\boldsymbol{v}\,\mathrm{d}t\|_2\le\int_\alpha^\beta\|\boldsymbol{v}\|_2\,\mathrm{d}t$。对任意分割把各段弦长相加，可知任意内接折线的长度都不超过 $\int_a^b\|\gamma'\|_2\,\mathrm{d}t$，所以上确界也不超过它。

第二步。γ' 在紧区间上一致连续。给定 $\varepsilon>0$，取足够细的分割，使每个小区间上任意两点的 γ' 相距小于 ε，并记 $\Delta t_j=t_j-t_{j-1}$。在第 j 个小区间上，

$$\gamma(t_j)-\gamma(t_{j-1})-\gamma'(t_{j-1})\Delta t_j=\int_{t_{j-1}}^{t_j}\big(\gamma'(t)-\gamma'(t_{j-1})\big)\,\mathrm{d}t,$$

由第一步的范数不等式，它的范数不超过 $\varepsilon\Delta t_j$；于是这一段的弦长与 $\|\gamma'(t_{j-1})\|_2\Delta t_j$ 之差不超过 $\varepsilon\Delta t_j$。同一小区间上，$\int\|\gamma'\|_2\,\mathrm{d}t$ 与 $\|\gamma'(t_{j-1})\|_2\Delta t_j$ 的差也不超过 $\varepsilon\Delta t_j$。两项相加后对 j 求和，速度积分与这条折线长度的差不超过 $2\varepsilon(b-a)$，所以上确界不小于速度积分减 $2\varepsilon(b-a)$。令 $\varepsilon\downarrow0$，得到反向不等式。 ∎

用这个公式可以计算示例 22.2中三条路径的长度，并检验圆周长公式。

示例 22.6　对角线段与圆周的弧长　对角线段 $\gamma(t)=(t,t)^{\top}$，$0\le t\le 1$，速度为 $(1,1)^{\top}$，速率为 $\sqrt{2}$，所以 $\ell(\gamma)=\int_0^1\sqrt{2}\,\mathrm{d}t=\sqrt{2}$。两个坐标各变化 1，走过的距离却不是 $1+1=2$，而是斜边的长度。

慢速路径 η 的速率为 $\sqrt{2}/2$，用时为 2，长度为 $\int_0^2(\sqrt{2}/2)\,\mathrm{d}u=\sqrt{2}$。往返路径 ρ 在两段上的速率都是 $\sqrt{2}$，总用时为 2，长度为 $2\sqrt{2}$。

半径为 r 的圆周可以参数化为 $t\mapsto(r\cos t,r\sin t)^{\top}$，$0\le t\le 2\pi$。速度为 $(-r\sin t,r\cos t)^{\top}$，速率恒为 r，长度为 $\int_0^{2\pi}r\,\mathrm{d}t=2\pi r$，与圆周长公式一致。

γ 与 η 的长度相同，因为速率减半恰好被用时加倍抵消；ρ 的长度是 γ 的两倍，因为弧长把经过的次数也计算在内。

记 $s(t)=\int_a^t\|\gamma'(u)\|_2\,\mathrm{d}u$ 为截至时刻 t 累计走过的路程，它就是里程表在时刻 t 的读数。在每个光滑段内部，s 对 t 的导数是速率 $\|\gamma'(t)\|_2$，因此常把长度权重简写为 $\mathrm{d}s=\|\gamma'(t)\|_2\,\mathrm{d}t$，读作“一小段时间 $\mathrm{d}t$ 内走过的一小段路程”。

22.2　第一类路径积分

第一类路径积分的被积对象是定义在曲线上的标量函数，例如铁丝各处的线密度或一条道路沿线各处的温度。每一小段的贡献是函数值乘这一小段的实际长度，因此它只需要路程这一个权重，不涉及方向。

22.2.1　定义与可积性

按弧长的积分　设一根铁丝沿路径 γ 放置，$h(\boldsymbol{x})$ 是它在点 $\boldsymbol{x}$ 处的线密度，即单位长度的质量。线密度为常数时，质量等于密度乘长度；密度随位置变化时，把铁丝切成许多小段，每段上的密度近似为常数。在参数小区间 $[t_{j-1},t_j]$ 对应的一段上取一个时刻 ξ_j，这段的质量约为

$$h(\gamma(\xi_j))\,\|\gamma'(\xi_j)\|_2\,(t_j-t_{j-1}),$$

即“该处密度”乘“该段长度”。把各段相加，就得到参数区间上函数 $h(\gamma(t))\|\gamma'(t)\|_2$ 的积分和，所以用这个函数的一元积分定义沿路径的累计。这里先讨论沿路径连续的密度；有限分段连续的密度可逐段处理。

定义 22.7 第一类路径积分 设 $\gamma:[a,b]\to\mathbb{R}^d$ 分段 C^1，h 在路径像集上连续。定义第一类路径积分为

$$\int_\gamma h\,\mathrm{d}s=\int_a^b h(\gamma(t))\|\gamma'(t)\|_2\,\mathrm{d}t. \tag{22.1}$$

右侧按各光滑段的一元 Riemann 积分相加，因被积函数分段连续而存在。

取 $h=1$，积分就是弧长 $\ell(\gamma)$；h 是非负线密度时，积分是铁丝的总质量。

若 $\ell(\gamma)>0$，比值

$$\bar h=\frac{1}{\ell(\gamma)}\int_\gamma h\,\mathrm{d}s$$

是 h 沿曲线按长度的平均值：沿一条道路每隔相同路程记录一次温度再求平均，记录越密，结果越接近 $\bar h$。这里的平均按路程加权，而不按参数时间加权。若一辆车在某段路上开得很慢，按时间平均会让这段路的温度占更大比重，按路程平均则不受车速影响。

用一根密度不均匀的半圆铁丝可以说明质量和平均线密度的计算。

示例 22.8 上半圆铁丝的质量与平均线密度 沿上半单位圆 $\gamma(t)=(\cos t,\sin t)^{\top}$，$0\le t\le\pi$，放一根铁丝，线密度为 $h(x,y)=y$，即越高的地方越重。速度为 $(-\sin t,\cos t)^{\top}$，速率恒为 1，所以总质量为

$$\int_\gamma y\,\mathrm{d}s=\int_0^{\pi}\sin t\,\mathrm{d}t=2.$$

铁丝长度为 π，平均线密度为 $\bar h=2/\pi\approx 0.64$。两端 $(\pm1,0)$ 处密度为零，顶点 $(0,1)$ 处密度为 1，平均值落在两者之间。

这条参数化的速率恒为 1，参数时间与路程同步增长，所以按时间平均也得到 $2/\pi$；速率不恒定时，两种平均一般不同。

22.2.2 积分的基本性质

下面的函数都假设在所讨论路径的像集上连续，或沿各光滑段分段连续，从而相应积分存在。把定义式 (22.1)代入一元 Riemann 积分的相应性质，就逐项得到这些结论。用铁丝质量来读，每条性质都有直接的含义。

线性　对函数 h, k 和实数 c，有

$$\int_\gamma (h+k)\,\mathrm{d}s = \int_\gamma h\,\mathrm{d}s + \int_\gamma k\,\mathrm{d}s, \qquad \int_\gamma ch\,\mathrm{d}s = c\int_\gamma h\,\mathrm{d}s.$$

两式都来自一元积分的线性；取 $c=-1$ 再用第一式，就得到差的积分等于积分之差。若铁丝由两种材料叠合而成，总质量等于两种材料各自的质量之和；把每一小段的密度同时放大 c 倍，总质量也放大 c 倍。

路径拼接　若 γ_1 的终点是 γ_2 的起点，记先走 γ_1、再走 γ_2 的拼接路径为 $\gamma_1 * \gamma_2$，则

$$\int_{\gamma_1*\gamma_2} h\,\mathrm{d}s = \int_{\gamma_1} h\,\mathrm{d}s + \int_{\gamma_2} h\,\mathrm{d}s.$$

拼接路径的参数区间由两段参数区间首尾相接而成，等式来自一元积分对区间的可加性。逐段计算折线和多边形边界上的积分，依据的就是这个等式。

两段路径有重叠部分时，重叠部分的贡献会计入两次。示例 22.2中的往返路径 ρ 由去程 γ 与原路返回的一段拼成；返回段 $(2-t, 2-t)^{\mathsf{T}}$，$1 \le t \le 2$，经换元 $u = 2-t$ 化为 γ 上的同一个积分，所以沿 ρ 的积分是沿 γ 的两倍。

重参数化与方向无关　同一根铁丝，无论从哪一端开始称量、量得快还是慢，质量都不变。改变快慢和方向，都可以用换参数表示。设 $t=\sigma(u)$ 是两个参数区间之间单调、端点相配的分段 C^1 微分同胚，新路径 $\gamma\circ\sigma$ 在时刻 u 位于 $\gamma(\sigma(u))$。链式法则给出新速度 $(\gamma\circ\sigma)'(u) = \gamma'(\sigma(u))\sigma'(u)$，所以新速率为 $\|\gamma'(\sigma(u))\|_2\,|\sigma'(u)|$。代入定义并用一元换元公式 $t=\sigma(u)$，得到

$$\int_{\gamma\circ\sigma} h\,\mathrm{d}s = \int_\gamma h\,\mathrm{d}s.$$

走得慢时速率变小，但用时按同一比例变长，乘积不变。σ 递减时路径反向，绝对值 $|\sigma'|$ 仍给出非负的长度权重，所以反向行进也不改变第一类积分。在示例 22.2中，$\eta = \gamma\circ\sigma$，其中 $\sigma(u) = u/2$，$0 \le u \le 2$，所以沿 η 与沿 γ 的第一类积分相同，弧长都是 $\sqrt{2}$。换参数只改变快慢和方向，不改变经过的次数，所以往返路径 ρ 不是 γ 的重参数化。

单调性　若在路径上处处有 $h \le k$，则

$$\int_\gamma h\,\mathrm{d}s \le \int_\gamma k\,\mathrm{d}s.$$

这是因为长度权重 $\|\gamma'\|_2$ 非负，被积函数的大小关系乘以权重后保持不变。密度处处较小的铁丝，总质量也较小。

绝对值不等式 由一元积分的绝对值不等式可得

$$\left|\int_\gamma h\,\mathrm{d}s\right| \le \int_\gamma |h|\,\mathrm{d}s \le \sup_C |h|\,\ell(\gamma).$$

连续函数在紧的像集 C 上有界，所以最后一项有限：累计量的绝对值不超过函数绝对值的上确界乘路径长度。例如在示例 22.8中，密度 y 不超过 1，质量 2 确实不超过 $1\cdot\pi$。

22.2.3 积分的计算

计算第一类路径积分分三步：给曲线选一条把它恰好走一遍的参数化；把 $h(\gamma(t))$ 乘速率 $\|\gamma'(t)\|_2$；在参数区间上做一元积分，有折点时在折点两侧分别计算再相加。先在示例 22.2的对角线段上积分一个线性函数。

示例 22.9 沿对角线段积分 $x+y$ 取 $\gamma(t)=(t,t)^{\mathsf T}$，$0\le t\le 1$，$h(x,y)=x+y$。沿路径有 $h(\gamma(t))=2t$，速率为 $\sqrt{2}$，所以

$$\int_\gamma h\,\mathrm{d}s = \int_0^1 2t\cdot\sqrt{2}\,\mathrm{d}t = \sqrt{2}.$$

线段长为 $\sqrt{2}$，平均值为 $\sqrt{2}/\sqrt{2}=1$，恰是 h 在线段中点 $(1/2,1/2)$ 的值，因为 h 沿这条线段随路程线性变化。

若漏掉速率而只计算 $\int_0^1 2t\,\mathrm{d}t=1$，得到的是按参数时间的累计，比按长度的累计少了速率因子 $\sqrt{2}$。第一类路径积分也不是线段下方某块平面区域的面积：区域积分按面积加权，这里的权重是沿线段的长度。

许多平面曲线写成函数图像 $y=\psi(x)$。设 ψ 在 $[a,b]$ 上为 C^1，取沿 x 递增的图像路径 $\gamma(x)=(x,\psi(x))^{\mathsf T}$，$a\le x\le b$。它以 x 本身作参数，速度为 $(1,\psi'(x))^{\mathsf T}$，于是

$$\int_\gamma h\,\mathrm{d}s = \int_a^b h(x,\psi(x))\sqrt{1+\psi'(x)^2}\,\mathrm{d}x.$$

根号是图像路径的速率：自变量前进 $\mathrm{d}x$ 时，曲线同时升高约 $\psi'(x)\,\mathrm{d}x$，斜边长约为 $\sqrt{1+\psi'(x)^2}\,\mathrm{d}x$。曲线越陡，同一个 $\mathrm{d}x$ 对应的路程越长，因此不能只写 $\mathrm{d}x$。

用这个公式可以计算一段抛物线铁丝的质量。

示例 22.10 抛物线铁丝的质量 沿抛物线段 $y = x^2$，$0 \le x \le 1$，放一根铁丝，线密度为 $h(x,y) = x$。这里 $\psi(x) = x^2$，$\psi'(x) = 2x$，速率为 $\sqrt{1+4x^2}$。令 $w = 1 + 4x^2$，则 $\mathrm{d}w = 8x\,\mathrm{d}x$，$w$ 从 1 变到 5，所以

$$\int_\gamma x\,\mathrm{d}s = \int_0^1 x\sqrt{1+4x^2}\,\mathrm{d}x = \frac{1}{8}\int_1^5 \sqrt{w}\,\mathrm{d}w = \frac{5\sqrt{5}-1}{12} \approx 0.85.$$

若漏写根号，只会得到 $\int_0^1 x\,\mathrm{d}x = 1/2$，丢掉了曲线变陡后多出的长度。

22.3 第二类路径积分

第一类积分只问每段有多长，做功问题还要问这段朝哪个方向走。推一辆车时，力与前进方向一致才完全用于推动；力与前进方向垂直时不做功；力与前进方向相反时做负功。描述这种累计之前，先要说清“每一点有一个力”是什么意思。

22.3.1 定义与可积性

向量场 力可以随位置变化：地面附近的重力处处竖直向下，太阳对行星的引力指向太阳，并随距离减弱。河水在每一点有一个流速，流速同样有大小和方向。按定义 17.2，这类对象是向量场 $\boldsymbol{F} : U \subseteq \mathbb{R}^d \to \mathbb{R}^d$：输入是位置，输出是放在该位置的一个向量，常画成从该点出发的箭头。输出与位置同维，才能与路径的速度向量作内积。

下面是本章反复使用的三个平面例子：

- 常向量场 $\boldsymbol{F}(x,y) = (0, -mg)^{\mathsf{T}}$ 描述地面附近质量为 m 的物体所受重力，其中 g 是重力加速度，箭头处处竖直向下、长度相同；
- $\boldsymbol{F}(x,y) = (x,y)^{\mathsf{T}}$ 的箭头从原点向外，离原点越远越长；
- $\boldsymbol{F}(x,y) = (-y,x)^{\mathsf{T}}$ 的箭头与以原点为圆心的圆相切，按逆时针方向，长度等于到原点的距离。它是绕原点以角速度 1 旋转的圆盘上各点的速度，本部分称它为旋转场。

旋转场与位置向量处处垂直，因为 $(-y)\cdot x + x \cdot y = 0$。

有向线积分 先看最简单的情形：常力 $\boldsymbol{F}$ 使物体沿直线产生位移 $\Delta\boldsymbol{r}$。中学物理中的功是 $\|\boldsymbol{F}\|_2 \|\Delta\boldsymbol{r}\|_2 \cos\theta$，其中 θ 是力与位移的夹角，这正是内积 $\boldsymbol{F}^{\mathsf{T}}\Delta\boldsymbol{r}$。把力分解为沿位移方向和垂直于位移方向的两部分，只有前一部分做功：$\theta < \pi/2$ 时功为正，$\theta = \pi/2$ 时为零，$\theta > \pi/2$ 时为负。

路线弯曲、力随位置变化时，把路径切成许多小段。参数小区间 $[t_{j-1}, t_j]$ 上的位移近似为 $\gamma'(\xi_j)(t_j - t_{j-1})$，力近似为常力 $\boldsymbol{F}(\gamma(\xi_j))$，这段的功约为

$$\boldsymbol{F}(\gamma(\xi_j))^{\top}\gamma'(\xi_j)\,(t_j - t_{j-1}).$$

各段相加就是参数区间上函数 $\boldsymbol{F}(\gamma(t))^{\top}\gamma'(t)$ 的积分和。这里乘的是速度向量本身，不是速率，所以位移的方向保留在被积函数中。

定义 22.11　第二类路径积分　设 $\gamma : [a,b] \to U$ 分段 C^1，$\boldsymbol{F} : U \to \mathbb{R}^d$ 为向量场。若 $\boldsymbol{F}$ 在路径像集上连续，定义**第二类路径积分**（vector line integral）为

$$\int_{\gamma} \boldsymbol{F}\cdot \mathrm{d}\boldsymbol{r} = \int_a^b \boldsymbol{F}(\gamma(t))^{\top}\gamma'(t)\,\mathrm{d}t. \tag{22.2}$$

记号 $\mathrm{d}\boldsymbol{r}$ 表示一小段有向位移 $\gamma'(t)\,\mathrm{d}t$，$\boldsymbol{F}\cdot\mathrm{d}\boldsymbol{r}$ 是这一小段上的功。在平面中，若 $\boldsymbol{F} = (P,Q)^{\top}$，路径为 $\gamma(t) = (x(t), y(t))^{\top}$，则被积函数是 $P\,x'(t) + Q\,y'(t)$，因此积分也写成 $\int_{\gamma} P\,\mathrm{d}x + Q\,\mathrm{d}y$：$P\,\mathrm{d}x$ 是力的水平分量在水平位移上做的功，$Q\,\mathrm{d}y$ 是竖直分量在竖直位移上做的功。三维中再加上第三个分量 R 对应的 $R\,\mathrm{d}z$。

$\boldsymbol{F}$ 在路径像集上连续时，复合函数 $\boldsymbol{F}\circ\gamma$ 在各光滑段上连续，被积函数在各段上连续，所以参数积分存在。

两类路径积分可以用单位切向量联系起来。在速度非零处，单位切向量 $\boldsymbol{\tau} = \gamma'/\|\gamma'\|_2$ 指向前进方向，于是

$$\boldsymbol{F}^{\top}\gamma'\,\mathrm{d}t = (\boldsymbol{F}^{\top}\boldsymbol{\tau})\,\|\gamma'\|_2\,\mathrm{d}t = (\boldsymbol{F}^{\top}\boldsymbol{\tau})\,\mathrm{d}s.$$

$\boldsymbol{F}^{\top}\boldsymbol{\tau}$ 是力在前进方向上的分量，称为切向分量。速度为零处，左侧的被积函数为零，右侧的长度权重 $\|\gamma'\|_2$ 也为零，不必定义 $\boldsymbol{\tau}$。所以第二类积分等于切向分量的第一类积分：功是沿前进方向的力乘走过的路程，再累计起来。两者的区别在于，切向分量依赖行进方向。反向行走时 $\boldsymbol{\tau}$ 变为 $-\boldsymbol{\tau}$，切向分量变号，积分也变号；第一类积分的被积函数则与方向无关。

若 $\boldsymbol{F}$ 是流体的速度场，沿闭路径的积分累计的是流速沿这条闭路径的切向分量，称为**环流**（circulation）。环流为正，表示流体总体上倾向于沿所选方向绕这条闭路径流动。例如沿单位圆逆时针行进时，旋转场 $(-y, x)^{\top}$ 的切向分量处处为 1，一周的环流是 $1 \times 2\pi = 2\pi$。

图 22.1用同一条线段对照两类积分：左图按长度累计常数密度，右图只累计位移的水平分量。

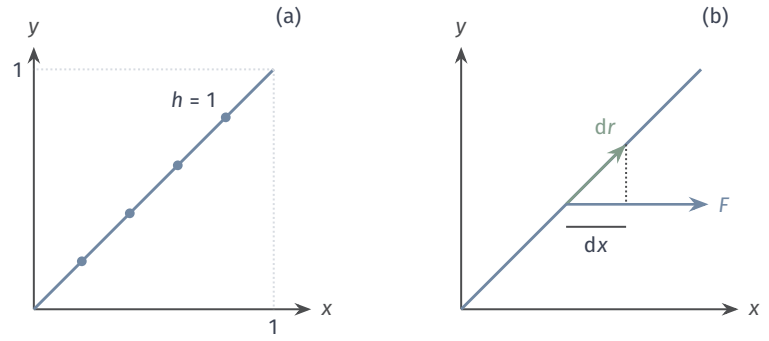


图 22.1 路径均为 $\gamma(t)=(t,t)^{\top}$，$0\le t\le 1$。(a) 常数线密度 $h=1$ 按弧长累计，得到 $\sqrt{2}$。(b) 常向量场 $\boldsymbol{F}=(1,0)^{\top}$ 只取位移的水平分量，做功为 1；图中 $\mathrm{d}x$ 是 $\mathrm{d}\boldsymbol{r}$ 的水平投影。相同路径、不同被积对象和权重给出不同积分。

22.3.2 积分的基本性质

以下向量场都假设在路径像集上连续。这些性质由内积的线性和一元 Riemann 积分的相应性质得到。线性说明功对力是线性的；拼接、方向反转和重参数化说明功怎样随路径变化；最后的不等式估计功的大小。

线性 对向量场 $\boldsymbol{F},\boldsymbol{G}$ 和实数 c，有

$$\int_{\gamma}(\boldsymbol{F}+\boldsymbol{G})\cdot\mathrm{d}\boldsymbol{r}=\int_{\gamma}\boldsymbol{F}\cdot\mathrm{d}\boldsymbol{r}+\int_{\gamma}\boldsymbol{G}\cdot\mathrm{d}\boldsymbol{r},\qquad \int_{\gamma}c\boldsymbol{F}\cdot\mathrm{d}\boldsymbol{r}=c\int_{\gamma}\boldsymbol{F}\cdot\mathrm{d}\boldsymbol{r}.$$

两个力同时作用时，合力做的功等于两个力各自做功之和。力放大 c 倍，功也放大 c 倍；$c<0$ 时力反向，功变号。两式结合，就得到差的积分等于积分之差。

路径拼接 若 γ_1 和 γ_2 首尾相接，则

$$\int_{\gamma_1*\gamma_2}\boldsymbol{F}\cdot\mathrm{d}\boldsymbol{r}=\int_{\gamma_1}\boldsymbol{F}\cdot\mathrm{d}\boldsymbol{r}+\int_{\gamma_2}\boldsymbol{F}\cdot\mathrm{d}\boldsymbol{r}.$$

先走一段再走一段，总功是两段的功之和。因此分段光滑路径可以逐段计算，但每段都要按这次行进的实际方向参数化。

方向反转 记反向路径为 $\gamma^{-}(u)=\gamma(a+b-u)$，$a\le u\le b$，它从 $\gamma(b)$ 出发、沿原路走回 $\gamma(a)$。由链式法则，它的速度是 $-\gamma'(a+b-u)$，与原速度相反；再用一元换元 $t=a+b-u$，得到

$$\int_{\gamma^{-}}\boldsymbol{F}\cdot\mathrm{d}\boldsymbol{r}=-\int_{\gamma}\boldsymbol{F}\cdot\mathrm{d}\boldsymbol{r}.$$

顺风骑车时风做正功，沿原路逆风骑回来，风在每一段都做等量的负功。第一类积分反向后不变，因为长度始终非负；有向位移反向则改变符号。特别地，往返路径 $\gamma * \gamma^{-}$ 上的第二类积分为零，而它的长度是 γ 的两倍；示例 22.2中的 ρ 就是对角线段上的这种往返路径。

重参数化 若 $t = \sigma(u)$ 为端点相配、严格递增的分段 C^1 微分同胚，则 $(\gamma\circ\sigma)'(u) = \gamma'(\sigma(u))\sigma'(u)$。在参数公式中应用换元 $t = \sigma(u)$，得到

$$\int_{\gamma\circ\sigma} \boldsymbol{F}\cdot \mathrm{d}\boldsymbol{r} = \int_{\gamma} \boldsymbol{F}\cdot \mathrm{d}\boldsymbol{r}.$$

也就是说，功只取决于经过哪些位置、朝哪个方向经过，与走得快慢无关。与第一类积分不同，这里乘的是 σ' 本身，而不是 $|\sigma'|$。严格递减的换参数把路径变成反向路径，换元后积分上下限交换，积分因此变号。换参数也不改变经过的次数：同一段路走两次，两次的功都会计入。

绝对值不等式 由积分的三角不等式和 Cauchy–Schwarz 不等式 $|\boldsymbol{F}^{\mathsf{T}}\boldsymbol{\tau}| \le \|\boldsymbol{F}\|_2$ 可得

$$\left|\int_{\gamma} \boldsymbol{F}\cdot \mathrm{d}\boldsymbol{r}\right| \le \int_{\gamma} \|\boldsymbol{F}\|_2 \,\mathrm{d}s.$$

功的绝对值不超过力的大小沿路程的累计；力处处沿前进方向时取等号。若力的大小不超过 M，路径长为 ℓ，功的绝对值便不超过 $M\ell$。

22.3.3 积分的计算

计算第二类路径积分时，按行进方向参数化路径，把场值与速度向量取内积，再做一元积分。与第一类积分相比，这里乘的是速度向量，而不是速率。先用图 22.1右图中的常力检验这一步骤。

示例 22.12 常力沿对角线段做功 取常向量场 $\boldsymbol{F} = (1,0)^{\mathsf{T}}$ 与对角线段 $\gamma(t) = (t,t)^{\mathsf{T}}$，$0 \le t \le 1$。速度为 $(1,1)^{\mathsf{T}}$，被积函数为 $1\cdot 1 + 0\cdot 1 = 1$，所以

$$\int_{\gamma} \boldsymbol{F}\cdot \mathrm{d}\boldsymbol{r} = \int_{0}^{1} 1 \,\mathrm{d}t = 1.$$

同一路径的长度为 $\sqrt{2}$。功为 1 而不是 $\sqrt{2}$，是因为水平方向的力只对位移的水平分量做功，而线段的水平跨度是 1。

再看地面附近的重力。它同样是常向量场，这次让路径任意弯曲。

示例 22.13　重力做功只取决于高度差　设质量为 m 的物体沿分段 C^1 平面路径 $\gamma(t) = (x(t), y(t))^{\top}$，$a \le t \le b$，从高度 $y(a)$ 移动到高度 $y(b)$，所受重力为 $\boldsymbol{F} = (0, -mg)^{\top}$。被积函数为 $\boldsymbol{F}(\gamma(t))^{\top}\gamma'(t) = -mg\,y'(t)$。在每个光滑段上用一元基本定理，再把各段相加，得到

$$\int_{\gamma} \boldsymbol{F}\cdot \mathrm{d}\boldsymbol{r} = \int_a^b (-mg)\,y'(t)\,\mathrm{d}t = -mg\big(y(b)-y(a)\big).$$

例如质量为 1 千克的物体下降 2 米，即 $y(b)-y(a) = -2$，取 $g \approx 9.8$ 米每二次方秒，无论沿斜坡还是沿弯曲的滑梯，重力都做功约 $9.8\times 2 = 19.6$ 焦。

被积函数中不含 $x'(t)$，水平移动不受重力影响，只有高度变化起作用。这个结果只依赖起点和终点的高度，第 22.4节将说明这并非偶然。

对平面图像路径 $\gamma(x) = (x, \psi(x))^{\top}$、$a \le x \le b$，其中 ψ 为 C^1，速度为 $(1, \psi'(x))^{\top}$。$\boldsymbol{F} = (P, Q)^{\top}$ 时有

$$\int_{\gamma} \boldsymbol{F}\cdot \mathrm{d}\boldsymbol{r} = \int_a^b \big[P(x,\psi(x)) + Q(x,\psi(x))\psi'(x)\big]\,\mathrm{d}x.$$

重力的功与路线无关。下面固定起点和终点，比较两条路线上的功，看一般向量场是否也是如此。

示例 22.14　半圆和直径　取上半圆 $\gamma(t) = (\cos t, \sin t)^{\top}$，$0 \le t \le \pi$，它从 $(1,0)$ 逆时针走到 $(-1,0)$，速度为 $(-\sin t, \cos t)^{\top}$，速率为 1，故长度 $\int_{\gamma} 1\,\mathrm{d}s = \pi$。另取起点和终点相同的直径 $\lambda(t) = (1-2t, 0)^{\top}$，$0 \le t \le 1$，速度为 $(-2, 0)^{\top}$。

对常场 $(1,0)^{\top}$，沿上半圆的功为 $\int_0^{\pi}(-\sin t)\,\mathrm{d}t = -2$，沿直径的功为 $\int_0^1(-2)\,\mathrm{d}t = -2$。两条路线都向左净移动了 2，水平向右的力在两条路线上做功都是 -2，恰等于函数 $\phi(x,y) = x$ 在终点与起点的差 $-1-1$。

对旋转场 $\boldsymbol{F} = (-y, x)^{\top}$，沿上半圆有 $\boldsymbol{F}(\gamma(t)) = (-\sin t, \cos t)^{\top}$，与速度相同，内积为 $\sin^2 t + \cos^2 t = 1$，故功为 π：质点一直顺着旋转方向走。沿直径，$\boldsymbol{F}(\lambda(t)) = (0, 1-2t)^{\top}$ 竖直，而位移水平，内积恒为零，功为 0。两条路线端点相同，旋转场做的功却不同。

对常场，功与路线无关；对旋转场，功依赖于路线。沿完整单位圆逆时针一周，质点回到起点，旋转场做功 2π 而不是零。图 22.2画出了旋转场与这两条路线。

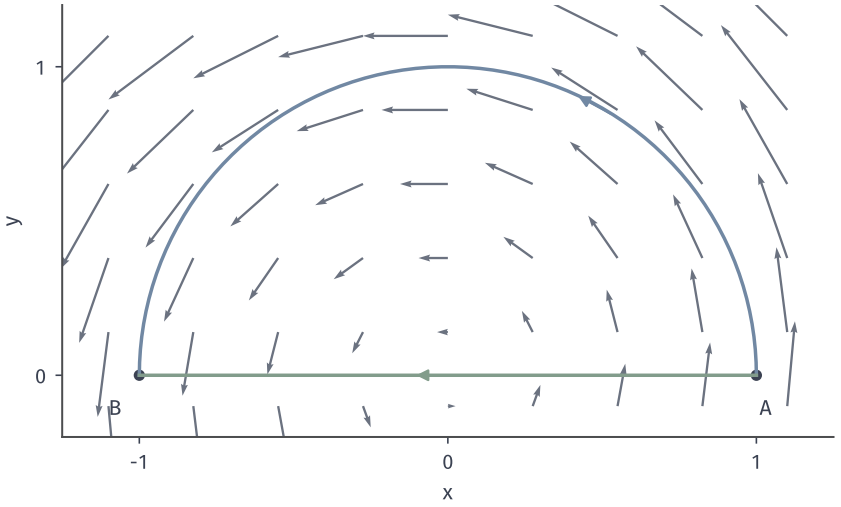


图 22.2 灰箭头为旋转场 $\boldsymbol{F}=(-y,x)^{\mathsf{T}}$，箭头长度统一缩放为实际场值的 $1/4$。两条路径都从 $A=(1,0)$ 到 $B=(-1,0)$：蓝色上半圆与场同向，积分为 π；绿色直径上场与位移垂直，积分为零。旋转场处处光滑，端点相同的两条路径上积分仍可不同；下一节说明势函数给出的路径无关条件。

22.4 路径无关与势函数

重力的功只依赖起点和终点的高度，旋转场的功却依赖路线。区别在于，重力的功可以写成一个只依赖位置的量在两端的差，这个量是 $-mgy$；旋转场没有这样的量。本节把这样的量称为势函数。先说明势函数怎样把沿途累计化为端点差，再证明功与路线无关时一定能构造出势函数，最后给出可以直接检查的微分条件，并说明定义域中有洞时这个条件为何不够。

22.4.1 势函数与路径积分

势函数 物理中，地面附近质量为 m 的物体在高度 y 处的重力势能为 $E_{\mathrm{p}}(x,y)=mgy$。重力等于势能梯度的相反向量：$-\nabla E_{\mathrm{p}}=(0,-mg)^{\mathsf{T}}$。物体下降时势能减少，减少的势能等于重力做的功。数学中习惯省去负号，取 $\phi=-E_{\mathrm{p}}$，要求向量场等于某个标量函数的梯度。

> **定义 22.15 势函数** 设 $U\subseteq\mathbb{R}^d$ 为非空开集，$\boldsymbol{F}:U\to\mathbb{R}^d$ 连续。若存在 $\phi\in C^1(U)$ 使 $\boldsymbol{F}=\nabla\phi$，称 ϕ 为 $\boldsymbol{F}$ 的**势函数**（potential function），称 $\boldsymbol{F}$ 为梯度场，也称保守场。

梯度指向函数增长最快的方向。所以在梯度非零处，梯度场的箭头指向 ϕ 增大、也就是势能 $-\phi$ 减小的方向：重力把物体拉向低处。例如 $\phi(x,y)=x^2+y^2$ 给出 $\boldsymbol{F}(x,y)=(2x,2y)^{\mathsf{T}}$，箭头从原点向外，因为离原点越远 ϕ 越大；常场 $(1,0)^{\mathsf{T}}$ 的一个势函数是 $\phi(x,y)=x$。

给势函数加一个常数，梯度不变，所以势函数不唯一。若 U 还是路径连通的，两个势函数只能相差一个常数。理由是：它们之差的梯度处处为零；路径连通的开集中，任意两点都能用域内折线连接；沿折线逐段使用中值公式（定理 17.18），可知这个差在任意两点取值相同。这与物理中势能的零点可以任选是同一件事：把地面还是桌面取作高度零点，算出的势能差都一样。

“保守”这个名称来自能量守恒。设质量为 m 的质点在力场 $\boldsymbol{F} = \nabla\phi$ 中按牛顿第二定律 $m\gamma''(t) = \boldsymbol{F}(\gamma(t))$ 运动，其中 γ 为 C^2 路径。依次用乘积法则、运动方程和链式法则，得到

$$\frac{\mathrm{d}}{\mathrm{d}t}\Big(\tfrac{1}{2}m\|\gamma'(t)\|_2^2\Big) = m\gamma''(t)^{\top}\gamma'(t) = \nabla\phi(\gamma(t))^{\top}\gamma'(t) = \frac{\mathrm{d}}{\mathrm{d}t}\phi(\gamma(t)),$$

所以动能与势能之和 $\frac{1}{2}m\|\gamma'\|_2^2 - \phi(\gamma)$ 的导数为零，不随时间变化。最后一个等号正是下面定理的核心：沿路径的功率 $\nabla\phi^{\top}\gamma'$ 恰是 $\phi\circ\gamma$ 的导数。

路径积分基本定理　一元基本定理说，导数在区间上的积分等于原函数在两端的差。把势函数与路径复合，得到一元函数 $t \mapsto \phi(\gamma(t))$。它的导数恰是第二类路径积分的被积函数，因此一元基本定理直接给出端点差。直观上，每一小段的功 $\nabla\phi^{\top}\Delta\boldsymbol{r}$ 近似等于 ϕ 在这一小段上的增量。这些增量相加时，中间各项逐一抵消，只剩终点值减起点值。

定理 22.16　路径积分基本定理　设 $U \subseteq \mathbb{R}^d$ 为开集，$\phi \in C^1(U)$，$\gamma : [a,b] \to U$ 分段 C^1。则

$$\int_{\gamma} \nabla\phi \cdot \mathrm{d}\boldsymbol{r} = \phi(\gamma(b)) - \phi(\gamma(a)). \tag{22.3}$$

证明　在每个光滑参数段 $[t_{j-1}, t_j]$ 上，链式法则给出

$$(\phi\circ\gamma)'(t) = \nabla\phi(\gamma(t))^{\top}\gamma'(t).$$

右侧是连续函数的复合与乘积，在该段上连续，所以对该段使用一元基本定理，得到 $\int_{t_{j-1}}^{t_j} \nabla\phi(\gamma(t))^{\top}\gamma'(t)\,\mathrm{d}t = \phi(\gamma(t_j)) - \phi(\gamma(t_{j-1}))$。对 $j = 1, \dots, n$ 相加，中间端点的值一正一负逐一抵消，只剩 $\phi(\gamma(b)) - \phi(\gamma(a))$。 ∎

用势能 $E_{\mathrm{p}} = -\phi$ 来读，式 (22.3)说：保守力沿任何路线做的功都等于起点势能减终点势能，即势能的下降量。示例 22.13的重力做功就是 $\phi(x,y) = -mgy$ 的情形。

这个定理有两个直接推论。第一，梯度场的积分只依赖端点：端点相同的两条路线，功相同。第二，闭路径的起点与终点重合，所以梯度场沿任意闭路径的积分为零。例如把书从地上拿到桌上再放回地上，重力在全过程中做的总功为零。方向反转时端点交换，端点差变号，这与第二类积分的方向反转性质一致。

知道势函数后，计算路径积分不必代入参数。

示例 22.17　用势函数计算沿半圆的积分　取 $\boldsymbol{F} = (2x, 2y)^{\mathsf{T}}$，它的势函数为 $\phi(x,y) = x^2 + y^2$。路径取示例 22.14中的上半圆 $\gamma(t) = (\cos t, \sin t)^{\mathsf{T}}$，$0 \le t \le \pi$，从 $(1,0)$ 走到 $(-1,0)$。由式 (22.3)，

$$\int_{\gamma} \boldsymbol{F} \cdot \mathrm{d}\boldsymbol{r} = \phi(-1,0) - \phi(1,0) = 1 - 1 = 0.$$

直接代入参数也得到同样结果：$\boldsymbol{F}(\gamma(t))^{\mathsf{T}}\gamma'(t) = 2\cos t\,(-\sin t) + 2\sin t\cos t = 0$。这个场在圆周上处处沿半径方向，与切线垂直。

第二个推论还可以用来否定势函数的存在。旋转场沿单位圆逆时针一周做功 $2\pi \neq 0$，所以它在 $\mathbb{R}^2$ 上没有势函数。

22.4.2 路径无关的等价判别

路径无关　由路径积分基本定理，有势函数就有功与路线无关。要讨论反方向，先把“与路线无关”说准确。比较同一对端点之间的不同路线，需要域内任意两点都能用路径连接。对欧氏空间中的开集，路径连通时任意两点之间还能选到域内的折线，因而能选到分段光滑路径。

定义 22.18　路径无关　设 $U \subseteq \mathbb{R}^d$ 为非空、开且路径连通的集合，$\boldsymbol{F} : U \to \mathbb{R}^d$ 连续。若对任意 $\boldsymbol{a}, \boldsymbol{b} \in U$ 及域内从 $\boldsymbol{a}$ 到 $\boldsymbol{b}$ 的任意两条分段 C^1 路径，第二类路径积分都相等，称 $\boldsymbol{F}$ 的路径积分与路径无关。

反方向的想法来自物理中定义势能的办法：选定一个参考点作为势能零点，把力从参考点到某点所做的功取负号，作为该点的势能。只有这个功与路线无关，这样定义的势能才是一个确定的数。下面的定理说明，路径无关、闭路径积分为零与势函数存在三者等价。

定理 22.19　路径无关的等价条件　设 $U \subseteq \mathbb{R}^d$ 非空、开且路径连通，$\boldsymbol{F} : U \to \mathbb{R}^d$ 连续。下列条件等价：

1. 存在 $\phi \in C^1(U)$ 使 $\nabla\phi = \boldsymbol{F}$；
2. $\boldsymbol{F}$ 的路径积分与路径无关；

3. 域内每条分段 C^1 闭路径的积分都为零。

证明 条件 1 推出条件 2，是路径积分基本定理的第一个推论。条件 2 推出条件 3：设 γ 是从 $\boldsymbol{a}$ 出发回到 $\boldsymbol{a}$ 的闭路径。停在 $\boldsymbol{a}$ 不动的常值路径也从 $\boldsymbol{a}$ 到 $\boldsymbol{a}$，它的速度为零，积分为零；由路径无关，γ 上的积分也为零。条件 3 推出条件 2：设 γ_1, γ_2 都从 $\boldsymbol{a}$ 到 $\boldsymbol{b}$。先沿 γ_1 走到 $\boldsymbol{b}$，再沿 γ_2 的反向路径 γ_2^- 走回 $\boldsymbol{a}$，拼成闭路径 $\gamma_1 * \gamma_2^-$。由拼接和方向反转性质，

$$0 = \int_{\gamma_1 * \gamma_2^-} \boldsymbol{F} \cdot \mathrm{d}\boldsymbol{r} = \int_{\gamma_1} \boldsymbol{F} \cdot \mathrm{d}\boldsymbol{r} - \int_{\gamma_2} \boldsymbol{F} \cdot \mathrm{d}\boldsymbol{r}.$$

最后由条件 2 构造势函数。固定参考点 $\boldsymbol{a} \in U$，对每个 $\boldsymbol{x} \in U$，取域内任意一条从 $\boldsymbol{a}$ 到 $\boldsymbol{x}$ 的分段 C^1 路径，令 $\phi(\boldsymbol{x})$ 为沿它的积分。路径无关保证这个数不依赖所选路线。下面计算偏导数。因为 U 开，存在 $r > 0$ 使以 $\boldsymbol{x}$ 为中心、半径 r 的球在 U 内。对 $0 < |h| < r$，到 $\boldsymbol{x} + h\boldsymbol{e}_j$ 的一条路径可以这样选：先沿原来的路径走到 $\boldsymbol{x}$，再沿第 j 个坐标方向走线段 $t \mapsto \boldsymbol{x} + t\boldsymbol{e}_j$，$t$ 从 0 到 h。线段的速度为 $\boldsymbol{e}_j$，场与速度的内积是第 j 个分量 F_j，于是

$$\phi(\boldsymbol{x} + h\boldsymbol{e}_j) - \phi(\boldsymbol{x}) = \int_0^h F_j(\boldsymbol{x} + t\boldsymbol{e}_j)\,\mathrm{d}t.$$

（$h < 0$ 时按有向积分理解。）右侧除以 h，是 F_j 在这条短线段上的平均值。F_j 连续，$h \to 0$ 时这个平均值趋于 $F_j(\boldsymbol{x})$，所以 $\partial_j \phi(\boldsymbol{x}) = F_j(\boldsymbol{x})$。所有偏导数都等于 $\boldsymbol{F}$ 的连续分量，故 $\phi \in C^1(U)$ 且 $\nabla\phi = \boldsymbol{F}$，得到条件 1。 ■

证明中的 ϕ 正是“从参考点出发做的功”。换一个参考点 $\boldsymbol{a}'$，ϕ 只改变一个常数，即从 $\boldsymbol{a}'$ 到 $\boldsymbol{a}$ 的功，这与势能零点可以任选一致。

22.4.3 势函数存在的微分判别

交叉偏导相等的必要条件 等价条件把势函数的存在归结为检查所有路径或所有闭路径，这无法逐条验证。我们希望找到只需对 $\boldsymbol{F}$ 求导就能检查的条件。若 $\boldsymbol{F} = \nabla\phi$，则 $F_j = \partial_j \phi$。当 $\boldsymbol{F}$ 本身是 C^1 时，ϕ 具有连续的二阶偏导数，由定理 17.31，混合偏导可以交换次序，于是 $\boldsymbol{F}$ 的分量之间必须满足一组关系。

定理 22.20　保守场的必要条件　设 $U \subseteq \mathbb{R}^d$ 为开集，$\boldsymbol{F} \in C^1(U;\mathbb{R}^d)$。若 $\boldsymbol{F} = \nabla \phi$，其中 $\phi \in C^1(U)$，则对所有 i, j 和 $\boldsymbol{x} \in U$，有

$$\partial_i F_j(\boldsymbol{x}) = \partial_j F_i(\boldsymbol{x}).$$

证明　由 $\partial_j \phi = F_j \in C^1(U)$ 可知 $\phi \in C^2(U)$，因此 $\partial_i F_j = \partial_i \partial_j \phi = \partial_j \partial_i \phi = \partial_j F_i$。 ■

在平面中，记 $\boldsymbol{F} = (P, Q)^{\mathsf{T}}$，条件只有一个：$\partial_x Q = \partial_y P$。差 $\partial_x Q - \partial_y P$ 度量向量场在一点附近的旋转程度。为看出这一点，计算沿一个小正方形边界的环流。

设正方形为 $[x_0, x_0+\delta] \times [y_0, y_0+\delta]$，按逆时针方向行走。下边向右，贡献 $\int_{x_0}^{x_0+\delta} P(x, y_0)\,\mathrm{d}x$；上边向左，贡献 $-\int_{x_0}^{x_0+\delta} P(x, y_0+\delta)\,\mathrm{d}x$。$P$ 在上下两边相差约 $\partial_y P\,\delta$，所以这两项之和约为 $-\partial_y P \cdot \delta \cdot \delta$。同理，右边向上、左边向下，两者的贡献之和约为 $\partial_x Q \cdot \delta^2$。因此小正方形的环流约为 $(\partial_x Q - \partial_y P)\,\delta^2$，即单位面积上的环流约为 $\partial_x Q - \partial_y P$，下面称它为旋转率。

保守场沿每条闭路径做功为零，小正方形也不例外，所以旋转率必须处处为零，与上面的必要条件一致。这里只是近似推理；边界环流与区域内旋转率的精确关系是 Green 公式（定理 24.9）。

两个例子可以对照。场 $(2x, 2y)^{\mathsf{T}}$ 满足 $\partial_x Q = 0 = \partial_y P$，它确实有势函数 $x^2 + y^2$。旋转场 $(-y, x)^{\mathsf{T}}$ 有 $\partial_x Q - \partial_y P = 1 - (-1) = 2 \neq 0$，它在每一点附近都在旋转，由上面的必要条件，它在任何非空开集上都没有势函数。这与单位圆上环流为 2π 的计算一致：2π 恰是旋转率 2 乘单位圆盘的面积 π。

星形域上的充分条件　交叉偏导相等只说明每个小区域内没有旋转，是局部条件；势函数却要在整个定义域上用一个函数表示。要从局部条件得到全局结论，还需要对定义域加条件。

一个便于直接构造的条件是星形：若存在 $\boldsymbol{a} \in U$，使从 $\boldsymbol{a}$ 到每个 $\boldsymbol{x} \in U$ 的整条线段都在 U 内，称 U 关于 $\boldsymbol{a}$ 星形。凸开集满足这一条件，整个 $\mathbb{R}^d$ 也满足。在星形域上，可以沿用路径无关等价条件证明中“从参考点出发做功”的办法定义势函数，并且总沿直线段从 $\boldsymbol{a}$ 走到 $\boldsymbol{x}$。

定理 22.21　星形域上势函数的构造　设 $U \subseteq \mathbb{R}^d$ 为关于 $\boldsymbol{a}$ 星形的开集，$\boldsymbol{F} \in C^1(U;\mathbb{R}^d)$，且对所有 i, j 有 $\partial_i F_j = \partial_j F_i$。则

$$\phi(\boldsymbol{x}) = \int_0^1 \boldsymbol{F}(\boldsymbol{a} + t(\boldsymbol{x} - \boldsymbol{a}))^{\mathsf{T}} (\boldsymbol{x} - \boldsymbol{a})\,\mathrm{d}t$$

属于 $C^1(U)$ 且满足 $\nabla\phi = \boldsymbol{F}$。因此 $\boldsymbol{F}$ 的路径积分与路径无关。

证明　记 $\boldsymbol{z} = \boldsymbol{x} - \boldsymbol{a}$。$\phi(\boldsymbol{x})$ 是 $\boldsymbol{F}$ 沿线段 $t \mapsto \boldsymbol{a} + t\boldsymbol{z}$，$0 \le t \le 1$，的第二类路径积分，因为这条线段的速度恒为 $\boldsymbol{z}$。固定 $\boldsymbol{x}$ 时，这条线段是 U 内的紧集，因而它的一个足够小的紧邻域仍在 U 内；当 $\boldsymbol{x}$ 在一个小范围内变动时，相应线段都留在这个紧邻域中。$\boldsymbol{F}$ 及其一阶偏导在紧邻域上连续因而有界，所以被积函数对 x_j 的偏导数有不依赖 t 的上界，可以用式 (21.1)在积分号下对 x_j 求导。

被积函数为 $\sum_i F_i(\boldsymbol{a}+t\boldsymbol{z})z_i$。对 x_j 求导时，z_j 对 x_j 的导数为 1，$F_i(\boldsymbol{a}+t\boldsymbol{z})$ 对 x_j 的导数由链式法则为 $t\,\partial_j F_i(\boldsymbol{a}+t\boldsymbol{z})$，所以偏导数为

$$F_j(\boldsymbol{a}+t\boldsymbol{z}) + t\sum_i z_i \partial_j F_i(\boldsymbol{a}+t\boldsymbol{z}).$$

交叉偏导条件把 $\partial_j F_i$ 换成 $\partial_i F_j$，而 $\sum_i z_i \partial_i F_j(\boldsymbol{a}+t\boldsymbol{z})$ 正是 $t \mapsto F_j(\boldsymbol{a}+t\boldsymbol{z})$ 的导数，于是

$$\begin{aligned} F_j(\boldsymbol{a}+t\boldsymbol{z}) + t\sum_i z_i \partial_j F_i(\boldsymbol{a}+t\boldsymbol{z}) &= F_j(\boldsymbol{a}+t\boldsymbol{z}) + t\sum_i z_i \partial_i F_j(\boldsymbol{a}+t\boldsymbol{z}) \\ &= \frac{\mathrm{d}}{\mathrm{d}t}\bigl[t F_j(\boldsymbol{a}+t\boldsymbol{z})\bigr]. \end{aligned}$$

对 t 从 0 积分到 1，由一元基本定理得 $\partial_j\phi(\boldsymbol{x}) = 1\cdot F_j(\boldsymbol{a}+\boldsymbol{z}) - 0 = F_j(\boldsymbol{x})$。这些偏导连续，所以 $\phi \in C^1(U)$；路径无关由前一定理得到。 ∎

用这个构造可以求出一个具体平面场的势函数。

示例 22.22　**沿线段构造势函数 x^2y**　取 $\boldsymbol{F}(x,y) = (2xy, x^2)^{\top}$，即 $P = 2xy$，$Q = x^2$。它定义在整个平面上，分量都是多项式，属于 C^1，并且 $\partial_y P = 2x = \partial_x Q$。整个平面关于 $\boldsymbol{a} = \boldsymbol{0}$ 星形，代入构造公式，

$$\phi(x,y) = \int_0^1 \bigl[2(tx)(ty)\,x + (tx)^2\,y\bigr]\,\mathrm{d}t = \int_0^1 3t^2x^2y\,\mathrm{d}t = x^2y.$$

直接求导可验证 $\nabla\phi = (2xy, x^2)^{\top}$。于是这个场沿任何从 $(0,0)$ 到 $(1,2)$ 的分段 C^1 路径做功都等于 $\phi(1,2) - \phi(0,0) = 2$。

星形域上的构造不依赖猜测：交叉偏导相等时，沿线段积分就给出势函数，任意路径上的功随之化为端点差。

穿孔平面上的反例　星形域的条件不能省略。下面的向量场在原点以外处处满足交叉偏导条件，在穿孔平面上却没有势函数。

示例 22.23　穿孔平面上的涡旋场　在穿孔平面 $\mathbb{R}^2 \setminus \{\mathbf{0}\}$ 上考虑

$$\boldsymbol{F}(x,y) = \left(-\frac{y}{x^2+y^2}, \frac{x}{x^2+y^2} \right)^{\top},$$

记它的两个分量为 P, Q。它与旋转场 $(-y, x)^{\top}$ 方向相同，都沿逆时针方向与以原点为圆心的圆相切，但大小改为到原点距离的倒数：离原点越近转得越快，类似于绕一根细涡管旋转的水流。原点处它没有定义。

先检查交叉偏导。由商的求导法则，

$$\partial_y P = -\frac{(x^2+y^2) - y\cdot 2y}{(x^2+y^2)^2} = \frac{y^2-x^2}{(x^2+y^2)^2},$$
$$\partial_x Q = \frac{(x^2+y^2) - x\cdot 2x}{(x^2+y^2)^2} = \frac{y^2-x^2}{(x^2+y^2)^2},$$

两者在穿孔平面上处处相等，所以这个场在原点以外的每一点附近都没有旋转。

再沿单位圆 $\gamma(t) = (\cos t, \sin t)^{\top}$，$0 \le t \le 2\pi$，逆时针走一周。在单位圆上 $x^2+y^2 = 1$，$\boldsymbol{F}(\gamma(t)) = (-\sin t, \cos t)^{\top}$ 与速度相同，内积为 1，积分为 2π。闭路径积分不为零，由路径无关的等价条件，$\boldsymbol{F}$ 在穿孔平面上没有势函数。

局部的交叉偏导条件在这里没有给出全局的势函数。这与星形域上的定理并不矛盾：穿孔平面不是星形域，对任一点 $\boldsymbol{a} \neq \mathbf{0}$，从 $\boldsymbol{a}$ 到 $-\boldsymbol{a}$ 的线段都经过原点。问题出在原点这个洞上，可以从两个角度理解。

第一，局部的势函数是极角。在不含原点的区域上，若能连续地选取点 (x,y) 的极角 θ，使 $x = r\cos\theta$、$y = r\sin\theta$，其中 $r = \sqrt{x^2+y^2}$，则直接求导可得 $\nabla\theta = \boldsymbol{F}$。例如在右半平面 $x > 0$ 上取 $\theta = \arctan(y/x)$，有 $\partial_x\theta = -y/(x^2+y^2)$，$\partial_y\theta = x/(x^2+y^2)$。在更大的区域，即去掉负半轴的平面 $\mathbb{R}^2 \setminus \{(x,0)^{\top} : x \le 0\}$ 上，取 $\theta \in (-\pi, \pi)$，它连续且仍满足 $\nabla\theta = \boldsymbol{F}$；这个区域关于 $(1,0)$ 星形，与星形域上的定理一致。

但在整个穿孔平面上无法连续地选取极角：从 $(1,0)$ 出发绕原点逆时针一周回到 $(1,0)$，极角连续地增加了 2π，起点和终点处的“势函数值”对不上。单位圆上的积分 2π 正是极角的这个增量。具体地，从 $(1,0)$ 到 $(-1,0)$，沿上半圆极角从 0 增加到 π，积分为 π；沿下半圆 $(\cos t, -\sin t)^{\top}$，$0 \le t \le \pi$，极角从 0 减少到 $-\pi$，积分为 $-\pi$。两条路线的功相差 2π，恰是绕原点一圈的积分。不绕原点的闭路径则没有这个问题。例如以 $(3,0)$ 为圆心、半径为 1 的圆整个落在右半平面中，那里 θ 是势函数，沿它的积分为零。

第二，从小正方形的环流看。交叉偏导相等说明每个小正方形的环流近似为零。若一条闭路径围住的区域整个在定义域内，可以把这个区域划分成许多小正方形；相邻正方形的公共边被沿相反方向各走一次，贡献相互抵消，只剩外边界，于是外边界的环流也为零。这一推理的精确形式就是 Green 公式（定理 24.9），它要求向量场在整个被围区域附近都有定义且连续可微。

单位圆围住的圆盘却包含原点，那里 $\boldsymbol{F}$ 没有定义，无法这样填满。场在定义域内的旋转率处处为零；非零环流与被排除的原点有关。对夹在两条绕原点闭路径之间、不含原点的环形区域作同样的划分，可知两条路径上的环流相等；所以绕原点逆时针一周的简单闭路径，积分都是 2π，而围住的区域不含原点的闭路径，积分为零。

相比之下，星形域上不会出现这样的洞：任何闭路径都可以沿线段向中心点 $\boldsymbol{a}$ 连续收缩而不离开定义域。这从几何上解释了，为什么在星形域上交叉偏导条件已经足以保证势函数存在。

22.5　本章小结

路径积分沿一次行进定义，不只沿一个点集定义。参数路径同时记录经过的位置、先后次序和经过次数；同一条线段可以对应快慢不同、方向不同或来回往返的路径。分段光滑路径的弧长是内接折线长度的上确界，等于速率 $\|\gamma'\|_2$ 的积分；一一的重参数化不改变弧长，重复行进则重复累计。

两类路径积分的被积对象和权重不同。第一类积分累计标量场，每小段的权重是长度 $\mathrm{d}s = \|\gamma'(t)\|_2\,\mathrm{d}t$，结果与行进方向和快慢无关，可用来算铁丝质量和按路程的平均值。第二类积分累计向量场与有向位移的内积 $\boldsymbol{F}(\gamma(t))^{\mathsf{T}}\gamma'(t)\,\mathrm{d}t$，等于切向分量的第一类积分；保向重参数化不改变它，反向行进使它变号，往返路径上的贡献相互抵消。沿闭路径的第二类积分称为环流。

功只依赖端点的条件，在路径连通开集上有三种等价表述：存在势函数 ϕ 使 $\boldsymbol{F} = \nabla\phi$，路径积分与路径无关，以及每条闭路径上的积分为零。有势函数时，路径积分基本定理把功化为端点差 $\phi(\gamma(b)) - \phi(\gamma(a))$。对连续可微的场，交叉偏导相等是必要条件，在星形域上也是充分条件，势函数可以沿线段积分构造出来。

定义域条件不能省略。穿孔平面上的涡旋场处处满足交叉偏导条件，绕原点一周的环流却是 2π，因为局部的势函数是极角，绕原点一圈后增加 2π。小正方形环流相消的推理只在被围区域整个落在定义域内时成立；它的精确形式是第 24章的 Green 公式。

第 23 章

曲面积分

路径积分沿一条细线累计：线密度乘弧长得到质量，力与位移的内积累加得到功。曲面积分把累计的范围从细线换成薄片，典型的问题有两个。第一个问题是求一张金属薄壳的质量。已知壳上每点每平方米有多少千克，把各小片的面密度乘面积加起来即可。第二个问题是求单位时间内有多少水穿过一张渔网。水在各点有速度，只有垂直于网面的速度分量才把水送到网的另一侧。

两个问题的被积对象不同。第一个问题的被积对象是曲面 S 上的标量函数 $h : S \to \mathbb{R}$，它给出每单位面积的密度，乘面积后相加得到质量、电荷等总量。第二个问题的被积对象是向量场 $\boldsymbol{F} : S \to \mathbb{R}^3$。要先取它垂直于曲面的分量，再乘面积相加，得到穿过曲面的通量。

本章要回答：怎样度量曲面上一小片的面积，怎样按面积累计标量面密度，以及怎样在规定了穿越方向之后累计向量场穿过曲面的量。

两类积分都需要知道曲面上一小片有多大，所以第一节先用参数化求出面积元，并证明面积不依赖参数的选取。第二节按面积累计标量场，结果与曲面朝哪一侧无关。通量还要规定从哪一侧穿到哪一侧算正，所以第三节先讨论曲面的定向，再定义第二类积分，并说明法向反转、参数次序与分片相容的作用。这些积分为下一章的 Gauss 公式与 Stokes 公式准备了边界上的累计。

本章以三维欧氏空间中的曲面为主，使用第 21章的区域积分与换元公式，以及第 17章的偏导数与 Jacobian。本章的参数积分都按有界 Jordan 区域上的 Riemann 积分理解；参数曲面、面积元和通量的标准构造可参考[1]。

[1] G. Strang, E. J. Herman, *Calculus Volume 3*, OpenStax, 2016

23.1 参数曲面与面积元

平面区域的面积就是它的 Jordan 面积。空间中的曲面一般是弯曲的，不能不经伸缩地摊平成平面区域，所以它的面积还没有定义。

地球表面上的一点可以用经度和纬度两个数确定。这就是一种参数化：用两个参数标记曲面上的点，把曲面上的累计转回二维参数域上计算。代

价是参数域中的面积一般不等于曲面上的实际面积。经纬度网格上同样大小的格子，在赤道附近和两极附近对应的地面面积并不相同，所以每一点都要乘一个面积放大倍数来校正。本节先说明怎样的参数化能描述一张面，再求出这个放大倍数，并证明由此得到的面积不依赖参数的选取。

23.1.1　曲面的参数化

正则曲面片　曲面的参数化是一个向量值映射：输入两个实数 (u,v)，输出空间中一点的三个坐标。并不是每个这样的映射都描述一张面。若改变两个参数时点只沿同一个方向移动，像集可能只是一条曲线。若不同参数在一块正面积的范围内对应同一些点，按参数累计就会把这块面计算两次。下面的定义用正则性和单次覆盖两个条件，分别排除这两种情况。

定义 23.1　正则参数曲面片　设 $E\subseteq\mathbb{R}^2$ 是有界闭区域，$E=\overline{E^\circ}$，其边界 ∂E 可用总面积任意小的有限个矩形覆盖。设 $\boldsymbol{r}$ 在 E 的一个开邻域内是 C^1 映射，写成

$$\boldsymbol{r}(u,v)=(x(u,v),y(u,v),z(u,v))^{\mathsf{T}}\in\mathbb{R}^3.$$

若不同参数只有在都属于 ∂E 时才允许表示同一点，且两个偏导向量 $\boldsymbol{r}_u,\boldsymbol{r}_v$ 在 E° 上处处线性无关，则称 $\boldsymbol{r}$ 为一个正则曲面片的参数化，曲面片记为 $S=\boldsymbol{r}(E)$。参数边界允许产生接缝或退化点；这些边界部分按零曲面面积处理。

定义中的两个偏导向量有直接的几何含义。固定 v 而只改变 u，点 $\boldsymbol{r}(u,v)$ 在曲面上画出一条参数曲线，它的速度向量是 $\boldsymbol{r}_u$；固定 u 而改变 v 得到另一条参数曲线，速度向量是 $\boldsymbol{r}_v$。这里 $\boldsymbol{r}_u,\boldsymbol{r}_v$ 都是三维向量，分别由三个坐标函数对同一个参数求偏导得到，并非某个标量函数的两个偏导数。

两个向量线性无关，几何上就是不共线。这时它们张成过该点的一个平面，即曲面的切平面。若这个条件不成立，像集可能根本不是一张面。

示例 23.2　像集退化为线段的参数映射　取 $E=[0,1]^2$ 和 $\boldsymbol{r}(u,v)=(u+v,0,0)^{\mathsf{T}}$。两个偏导向量都等于 $(1,0,0)^{\mathsf{T}}$，因而线性相关。当 (u,v) 取遍 E 时，$u+v$ 取遍 $[0,2]$，所以像集是 x 轴上的线段 $\{(x,0,0)^{\mathsf{T}}:0\le x\le 2\}$。整个正方形被压到这条线段上，像集上没有两个不共线的切方向，也没有面积可言；这个映射不满足正则性条件。

正则性条件排除了这种压扁的映射。单次覆盖条件处理另一种情况：像集确实是一张面，但被参数重复计数。

示例 23.3　圆柱面的单次覆盖与二重覆盖　高为 1 的单位圆柱面可以写成

$$\boldsymbol{r}(\theta, z) = (\cos\theta, \sin\theta, z)^{\mathsf{T}}$$

$$z \in [0, 1].$$

偏导向量 $\boldsymbol{r}_\theta = (-\sin\theta, \cos\theta, 0)^{\mathsf{T}}$ 与 $\boldsymbol{r}_z = (0, 0, 1)^{\mathsf{T}}$ 处处线性无关，正则性没有问题，需要检查的只有覆盖次数。若 $\theta \in [0, 2\pi]$，只有 $\theta = 0$ 与 $\theta = 2\pi$ 两条边界线表示同一条接缝，这是定义允许的。若 $\theta \in [0, 4\pi]$，则对 $0 < \theta_0 < 2\pi$ 和 $0 < z < 1$，点 $\boldsymbol{r}(\theta_0, z)$ 同时由参数域内部的 (θ_0, z) 和 $(\theta_0 + 2\pi, z)$ 表示；按参数累计会把整张柱面计入两次，因此这一参数域不符合定义。

所以，不同参数表示同一点的情形只允许出现在参数边界上，形成接缝；参数域内部的点不能与其他任何参数点表示同一点。

本章反复使用的例子是 $\boldsymbol{r}(u, v) = (u, v, u + v)^{\mathsf{T}}$、$E = [0, 1]^2$，下文称它为斜平面片。它描述平面 $z = x + y$ 上位于单位正方形上方的一块平行四边形，两个切向量分别为 $\boldsymbol{r}_u = (1, 0, 1)^{\mathsf{T}}$ 和 $\boldsymbol{r}_v = (0, 1, 1)^{\mathsf{T}}$。前两个坐标就是参数本身，所以不同参数给出不同点；两个切向量不共线，所以它满足正则曲面片的定义。

叉积　要求曲面的面积，先看参数域中的一个小矩形 $[u, u+\Delta u] \times [v, v+\Delta v]$ 被映成什么形状。由 $\boldsymbol{r}$ 的可微性，在 $\Delta u, \Delta v$ 很小时有线性近似

$$\boldsymbol{r}(u + \Delta u, v + \Delta v) \approx \boldsymbol{r}(u, v) + \boldsymbol{r}_u \Delta u + \boldsymbol{r}_v \Delta v,$$

其中 $\boldsymbol{r}, \boldsymbol{r}_u, \boldsymbol{r}_v$ 都在 (u, v) 处取值。于是小矩形的四个顶点近似映为 $\boldsymbol{r}$、$\boldsymbol{r} + \boldsymbol{r}_u \Delta u$、$\boldsymbol{r} + \boldsymbol{r}_v \Delta v$ 和 $\boldsymbol{r} + \boldsymbol{r}_u \Delta u + \boldsymbol{r}_v \Delta v$，它们正是以 $\boldsymbol{r}_u \Delta u$ 和 $\boldsymbol{r}_v \Delta v$ 为两边的平行四边形的顶点。所以曲面上的小片近似是切平面内的一个小平行四边形，问题归结为：怎样由两条边向量求平行四边形的面积。

在平面上，两个边向量排成 2×2 矩阵，其行列式的绝对值就是这个面积。现在两条边是三维向量，排成的是 3×2 矩阵，没有行列式可取。三维空间中常用叉积同时记录这个面积和平行四边形所在平面的垂直方向。对 $\boldsymbol{a}, \boldsymbol{b} \in \mathbb{R}^3$，定义叉积

$$\boldsymbol{a} \times \boldsymbol{b} = (a_2 b_3 - a_3 b_2,\ a_3 b_1 - a_1 b_3,\ a_1 b_2 - a_2 b_1)^{\mathsf{T}}.$$

例如 $(1, 0, 0)^{\mathsf{T}} \times (0, 1, 0)^{\mathsf{T}} = (0, 0, 1)^{\mathsf{T}}$：$x$ 轴方向与 y 轴方向的单位向量张成面积为 1 的正方形，叉积是长度为 1、沿 z 轴的向量。

后面的面积和法向计算要用到叉积的三条性质，下面逐一核对。第一，叉积垂直于 $\boldsymbol{a}$ 和 $\boldsymbol{b}$。直接展开

$$\boldsymbol{a}^{\top}(\boldsymbol{a}\times\boldsymbol{b}) = a_1(a_2b_3 - a_3b_2) + a_2(a_3b_1 - a_1b_3) + a_3(a_1b_2 - a_2b_1),$$

右端六项两两抵消，结果为 0；对 $\boldsymbol{b}$ 同理。垂直于同一平面的方向有相反的两个，叉积按右手规则选取其中之一：右手四指从 $\boldsymbol{a}$ 弯向 $\boldsymbol{b}$ 时，拇指指向 $\boldsymbol{a}\times\boldsymbol{b}$。

第二，叉积的长度等于 $\boldsymbol{a},\boldsymbol{b}$ 张成的平行四边形的面积。把两边按分量展开，可以验证 Lagrange 恒等式

$$\|\boldsymbol{a}\times\boldsymbol{b}\|_2^2 = \|\boldsymbol{a}\|_2^2\|\boldsymbol{b}\|_2^2 - (\boldsymbol{a}^{\top}\boldsymbol{b})^2.$$

记 $\theta\in[0,\pi]$ 为两向量的夹角，则 $\boldsymbol{a}^{\top}\boldsymbol{b} = \|\boldsymbol{a}\|_2\|\boldsymbol{b}\|_2\cos\theta$，代入得 $\|\boldsymbol{a}\times\boldsymbol{b}\|_2 = \|\boldsymbol{a}\|_2\|\boldsymbol{b}\|_2\sin\theta$。以 $\boldsymbol{a}$ 为底边时，平行四边形的高是 $\|\boldsymbol{b}\|_2\sin\theta$，所以叉积长度正是“底乘高”。特别地，叉积为零当且仅当两向量线性相关，即平行四边形退化为线段或一点。Lagrange 恒等式的右端正是 Gram 矩阵 $\begin{bmatrix}\boldsymbol{a}^{\top}\boldsymbol{a} & \boldsymbol{a}^{\top}\boldsymbol{b}\\ \boldsymbol{a}^{\top}\boldsymbol{b} & \boldsymbol{b}^{\top}\boldsymbol{b}\end{bmatrix}$ 的行列式，所以面积也等于两条边的 Gram 行列式的平方根。这种写法只用内积，不依赖叉积，也适用于高维空间中由两个向量张成的平行四边形。

第三，叉积对每个因子都是线性的，交换两个因子的次序会变号：从定义式直接看出 $\boldsymbol{b}\times\boldsymbol{a} = -\boldsymbol{a}\times\boldsymbol{b}$，特别地 $\boldsymbol{a}\times\boldsymbol{a} = \boldsymbol{0}$。这与右手规则一致：交换次序后四指的弯曲方向相反，拇指也随之反向。

把这些性质用到小平行四边形上。由线性，$(\boldsymbol{r}_u\Delta u)\times(\boldsymbol{r}_v\Delta v) = (\boldsymbol{r}_u\times\boldsymbol{r}_v)\Delta u\Delta v$；再由第二条性质，小曲面片的面积近似为

$$\|\boldsymbol{r}_u\times\boldsymbol{r}_v\|_2\,\Delta u\,\Delta v.$$

因此 $\|\boldsymbol{r}_u\times\boldsymbol{r}_v\|_2$ 就是参数化在该点的面积放大倍数：参数域中面积为 $\Delta u\Delta v$ 的小块，在曲面上变成面积约为这个倍数乘 $\Delta u\Delta v$ 的小片。同样由第二条性质，正则性条件“两个切向量线性无关”可以等价地写成 $\boldsymbol{r}_u\times\boldsymbol{r}_v\neq\boldsymbol{0}$，即放大倍数处处为正。

平面情形可以用来核对这个倍数。若曲面就在平面 $z=0$ 内，即 $\boldsymbol{r}(u,v) = (x(u,v),y(u,v),0)^{\top}$，则 $\boldsymbol{r}_u\times\boldsymbol{r}_v = (0,0,x_uy_v - x_vy_u)^{\top}$，其长度正是映射 $(u,v)\mapsto(x,y)$ 的 Jacobian 行列式的绝对值。这与第 21.3节换元公式中的面积权重 $|\det\boldsymbol{J}_T|$ 一致；叉积长度是这个权重在三维空间中的推广。

23.1.2 曲面面积的表示

面积元与面积 把参数域分成许多小矩形，由小平行四边形的面积近似，每块在曲面上的像的面积约为放大倍数乘参数面积，曲面的总面积约为这些乘积之和。小矩形越细，线性近似越准确，求和的极限就是放大倍数在参数域上的积分。

这里直接把这个积分取作曲面面积的定义，而不像弧长那样用内接折线的上确界定义，因为曲面上的类似做法会失败。在一段有限高的圆柱面上，可以构造顶点都在柱面上的三角形网格（称为 Schwarz 灯笼）：网格越来越细，三角形与柱面的夹角却不趋于零，三角形总面积可以趋于无穷。切平面上的平行四边形则贴着曲面，不会出现这个问题。

定义 23.4　曲面面积 在单次覆盖的正则曲面片上，令 $J_S = \|\boldsymbol{r}_u \times \boldsymbol{r}_v\|_2$。定义面积为

$$\operatorname{area}(S) = \iint_E J_S(u,v)\,\mathrm{d}u\,\mathrm{d}v.$$

面积元记为 $\mathrm{d}S = J_S(u,v)\,\mathrm{d}u\,\mathrm{d}v$。

J_S 在紧参数域上连续，所以积分存在。有限分片曲面的面积逐片相加；各片只沿边界接合，接缝的参数原像须能被任意小总面积的有限盒覆盖，以免重复累计。

用这一定义计算斜平面片的面积，并用初等几何核对结果。

示例 23.5　斜平面片的面积 对斜平面片 $\boldsymbol{r}(u,v) = (u, v, u+v)^{\mathsf{T}}$、$E = [0,1]^2$，按叉积的定义计算

$$\begin{aligned}\boldsymbol{r}_u \times \boldsymbol{r}_v &= (1,0,1)^{\mathsf{T}} \times (0,1,1)^{\mathsf{T}} \\ &= (0\cdot 1 - 1\cdot 1,\; 1\cdot 0 - 1\cdot 1,\; 1\cdot 1 - 0\cdot 0)^{\mathsf{T}} = (-1,-1,1)^{\mathsf{T}},\end{aligned}$$

故 $J_S = \|(-1,-1,1)^{\mathsf{T}}\|_2 = \sqrt{3}$ 处处成立，曲面面积为

$$\operatorname{area}(S) = \int_0^1 \int_0^1 \sqrt{3}\,\mathrm{d}u\,\mathrm{d}v = \sqrt{3}.$$

用初等几何核对：两条边 $\boldsymbol{r}_u, \boldsymbol{r}_v$ 的长度都是 $\sqrt{2}$，内积为 1，夹角余弦为 $1/2$，即夹角为 60°；平行四边形面积为 $\sqrt{2}\cdot\sqrt{2}\cdot\sin 60^\circ = \sqrt{3}$，与积分结果相同。

参数正方形的面积只有 1，曲面片的面积却是 $\sqrt{3}$：每个参数小块都被放大 $\sqrt{3}$ 倍。图 23.1将参数小块与实际斜面小块对应起来，显示叉积长度校正的是哪一个面积。

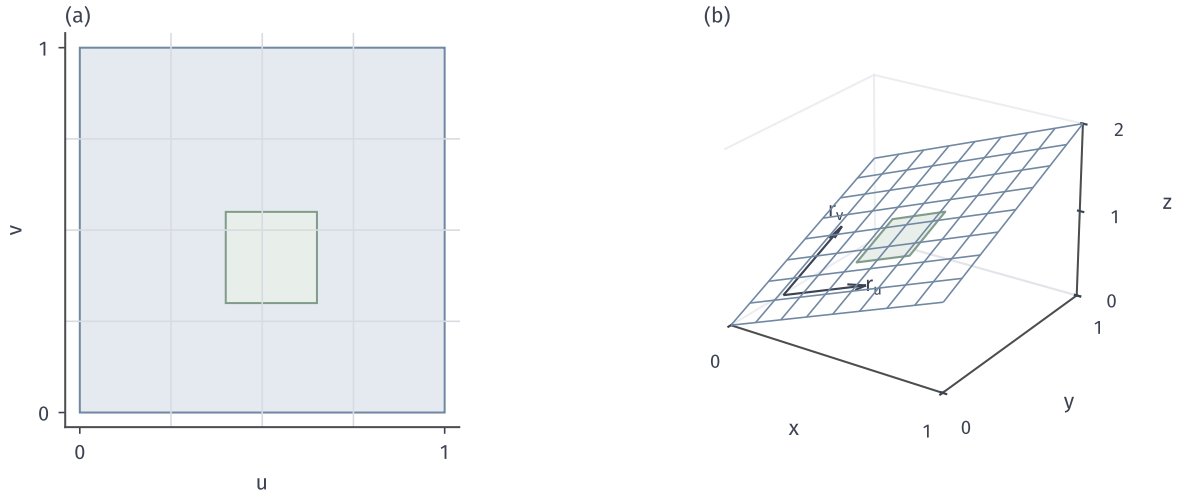


图 23.1 参数化 $r(u,v) = (u, v, u+v)^{\mathsf{T}}$ 把单位正方形映为斜平面片，绿色块为同一参数子区间及其像。两切向量 $r_u = (1,0,1)^{\mathsf{T}}$、$r_v = (0,1,1)^{\mathsf{T}}$ 在右侧按 0.4 倍画出，叉积长度为 $\sqrt{3}$。每个参数面积都放大 $\sqrt{3}$ 倍，故不能把 $\mathrm{d}u\,\mathrm{d}v$ 直接当成 $\mathrm{d}S$。

重参数化 同一张面可以用不同参数标记。面积是曲面本身的属性，不应随标记方式改变；先在斜平面片上核对一次具体的换参数。

示例 23.6 拉伸一个参数不改变面积 在斜平面片中令 $u = 2\xi$，则

$$\tilde{\boldsymbol{r}}(\xi, v) = (2\xi, v, 2\xi + v)^{\mathsf{T}}$$
$$(\xi, v) \in [0, 1/2] \times [0, 1]$$

描述同一块平行四边形，新参数域的面积只有 $1/2$。另一方面，$\tilde{\boldsymbol{r}}_\xi = (2,0,2)^{\mathsf{T}} = 2\boldsymbol{r}_u$，$\tilde{\boldsymbol{r}}_v = \boldsymbol{r}_v$，由叉积的线性，$\tilde{\boldsymbol{r}}_\xi \times \tilde{\boldsymbol{r}}_v = 2(\boldsymbol{r}_u \times \boldsymbol{r}_v) = 2(-1,-1,1)^{\mathsf{T}}$，放大倍数为 $2\sqrt{3}$。因此

$$\int_0^1 \int_0^{1/2} 2\sqrt{3}\,\mathrm{d}\xi\,\mathrm{d}v = \sqrt{3},$$

与示例 23.5的结果相同。

参数域缩小一半，每点的放大倍数恰好加倍，两者相互抵消。下面的定理说明，这种抵消对一般的单次覆盖换参数都成立。

定理 23.7　重参数化下的面积元　设 $\boldsymbol{r}:E\to S$ 是正则曲面片的参数化，$T:\widetilde{E}\to E$ 是参数域之间的双射，在 $\widetilde{E}$ 的一个开邻域内为 C^1 映射，并且限制在 $\widetilde{E}^\circ$ 上是到 E° 的 C^1 微分同胚。若 $\widetilde{\boldsymbol{r}}=\boldsymbol{r}\circ T$ 仍满足曲面片条件，则

$$\widetilde{\boldsymbol{r}}_\xi\times\widetilde{\boldsymbol{r}}_\eta=\det\boldsymbol{J}_T\,(\boldsymbol{r}_u\times\boldsymbol{r}_v)\circ T,$$
$$\widetilde{J}_S=(J_S\circ T)\,|\det\boldsymbol{J}_T|.$$

两组参数由此给出同一面积。

证明　记 $T(\xi,\eta)=(u(\xi,\eta),v(\xi,\eta))$。链式法则给出 $\widetilde{\boldsymbol{r}}_\xi=\boldsymbol{r}_u u_\xi+\boldsymbol{r}_v v_\xi$ 和 $\widetilde{\boldsymbol{r}}_\eta=\boldsymbol{r}_u u_\eta+\boldsymbol{r}_v v_\eta$，其中右端各量在 $T(\xi,\eta)$ 处取值。用叉积对每个因子的线性展开，得到四项：

$$\begin{aligned}\widetilde{\boldsymbol{r}}_\xi\times\widetilde{\boldsymbol{r}}_\eta=\;&u_\xi u_\eta(\boldsymbol{r}_u\times\boldsymbol{r}_u)+u_\xi v_\eta(\boldsymbol{r}_u\times\boldsymbol{r}_v)\\&+v_\xi u_\eta(\boldsymbol{r}_v\times\boldsymbol{r}_u)\\&+v_\xi v_\eta(\boldsymbol{r}_v\times\boldsymbol{r}_v).\end{aligned}$$

由 $\boldsymbol{a}\times\boldsymbol{a}=\boldsymbol{0}$，第一、四项为零；交换叉积次序会变号，即 $\boldsymbol{r}_v\times\boldsymbol{r}_u=-\boldsymbol{r}_u\times\boldsymbol{r}_v$，于是第三项可与第二项合并。因此

$$\widetilde{\boldsymbol{r}}_\xi\times\widetilde{\boldsymbol{r}}_\eta=(u_\xi v_\eta-v_\xi u_\eta)(\boldsymbol{r}_u\times\boldsymbol{r}_v)\circ T,$$

括号内正是 $\det\boldsymbol{J}_T$，这就是第一式；两边取长度得到第二式。把第二式在新参数域上积分，并应用经典二维换元公式，得到

$$\iint_{\widetilde{E}}(J_S\circ T)\,|\det DT|=\iint_E J_S.$$

若换元只在参数域内部正则，先在远离边界的紧子域上应用公式，再利用连续有界权重和 Jordan 边界条件取极限。两组参数因而给出相同面积。 ∎

几何上，这个证明把两步面积放大接在一起：新参数的小方块先由 T 映成原参数域中面积约为 $|\det\boldsymbol{J}_T|$ 倍的小块，这个小块再由 $\boldsymbol{r}$ 映到曲面，面积又乘 J_S。二维换元公式恰好把第一步的倍数吸收掉，所以只剩下曲面本身的面积。在示例 23.6中，$T(\xi,v)=(2\xi,v)$，$\det\boldsymbol{J}_T=2$，这正是放大倍数加倍的来源。

行列式的绝对值保证面积非负；行列式本身的符号则记录参数次序是否翻转。例如在斜平面片上交换两个参数，令 $T(\xi,\eta)=(\eta,\xi)$，即 $\widetilde{\boldsymbol{r}}(\xi,\eta)=\boldsymbol{r}(\eta,\xi)=(\eta,\xi,\xi+\eta)^{\mathsf T}$，则 $\det\boldsymbol{J}_T=-1$，叉积由 $(-1,-1,1)^{\mathsf T}$ 变为 $(1,1,-1)^{\mathsf T}$，

长度不变而方向相反。面积不使用这个方向，后面选取通量的法向时则要用到它。

定理还要求 T 是双射。若参数在正面积的范围内重复覆盖，参数积分就会重复累计。示例 23.3中，$\boldsymbol{r}_\theta \times \boldsymbol{r}_z = (\cos\theta, \sin\theta, 0)^{\top}$，$J_S = 1$；$\theta \in [0, 2\pi]$ 时参数积分给出柱面面积 2π，$\theta \in [0, 4\pi]$ 时却给出 4π，不能当作单次覆盖的曲面面积。

分片曲面　有些曲面不能用一张正则曲面片描述。单位立方体的表面由六个正方形组成，棱上没有切平面。球面虽然可以用一张球坐标参数片覆盖（两极位于参数边界上，切向量在那里退化），也常分成上下两个半球分别处理。本章只处理有限分片的情形：把曲面写成有限张正则曲面片的并，各片内部不重叠，交接部分在相邻曲面片中面积均为零，整个曲面的面积由各片的面积相加。

例如立方体表面的面积就是六个单位正方形的面积之和 6，十二条棱的面积为零，不需要在接缝上另加一项。后面的两类曲面积分同样可以逐片计算再相加。无界曲面，或不能这样由有限张正则曲面片覆盖的曲面，还需另外处理覆盖和可积性条件。

23.2　第一类曲面积分

有了面积，就可以回到本章开头的第一个问题：在曲面上累计一个标量密度。这类积分只用到小片的面积，不涉及方向。

23.2.1　积分的定义和可积性

按面积的积分　设一张薄金属壳占据曲面 S，在点 $\boldsymbol{x}$ 附近每单位面积的质量为 $h(\boldsymbol{x})$（单位如千克每平方米）。把壳分成许多小片 S_j，在每片内取一点 $\boldsymbol{x}_j$。每片很小时，片内面密度近似为常数 $h(\boldsymbol{x}_j)$，这一片的质量约为 $h(\boldsymbol{x}_j)\,\operatorname{area}(S_j)$。把各片质量相加，再让分割越来越细，就得到面密度对面积的积分。带电薄壳上的电荷量、涂层表面的涂料用量都是同一种累计。用参数表示时，每片的面积是面积元，所以把密度与面积权重相乘，再在参数域上积分。

定义 23.8　第一类曲面积分　设 h 是 S 上的连续标量函数，定义它的**第一类曲面积分**（scalar surface integral）为

$$\int_S h \,\mathrm{d}S = \iint_E h(\boldsymbol{r}(u,v)) J_S(u,v)\,\mathrm{d}u\,\mathrm{d}v. \tag{23.1}$$

右侧被积函数连续，因而积分存在且有限。

式 (23.1)右端的计算顺序是：用参数找到曲面上的点，读出该点的密度，乘该点的面积放大倍数，再在参数域上积分。对定理 23.7中的重参数化，把 $h\circ\boldsymbol{r}$ 一并代入换元公式，可见积分值不变。取 $h=1$ 得到面积，取非负面密度得到质量。例如在斜平面片上，常数密度 $h=2$ 给出

$$\int_S 2\,\mathrm{d}S=\int_0^1\int_0^1 2\sqrt{3}\,\mathrm{d}u\,\mathrm{d}v=2\sqrt{3},$$

即面积为 $\sqrt{3}$、每单位面积重 2 的薄片，总质量为 $2\sqrt{3}$。

除了总量，第一类积分还给出曲面上的平均值。设 $0<\operatorname{area}(S)<\infty$ 且 h 在 S 上连续，则

$$\frac{1}{\operatorname{area}(S)}\int_S h\,\mathrm{d}S$$

是 h 按面积加权的平均。若 h 表示地球表面各点的气温，这个量就是全球表面平均气温：每块地面按其实际面积参与平均，而不是按经纬度网格的格子数参与平均。

第一类积分继承参数区域积分的线性、单调性和绝对值估计。有限分片曲面上逐片求和，公共接缝不另计面积。特别地，连续密度满足

$$\left|\int_S h\,\mathrm{d}S\right|\le \sup_S|h|\,\operatorname{area}(S).$$

质量和平均值都只依赖每小片的大小，面积权重又非负，与从哪一侧看曲面无关。所以把曲面的朝向反过来，第一类积分不变。

23.2.2 积分的计算

计算第一类曲面积分分三步：选一个单次覆盖的正则参数化，把 h 与参数化复合，再乘叉积的长度后在参数域上积分。最常见的两种参数化是函数图像和球坐标。

若曲面是函数 $z=\psi(x,y)$ 在区域 D 上的图像，其中 D 满足定义 23.1对参数域的要求，ψ 在 D 的开邻域内为 C^1，就可以取 $\boldsymbol{r}(x,y)=(x,y,\psi(x,y))^{\mathsf{T}}$。此时 $\boldsymbol{r}_x=(1,0,\psi_x)^{\mathsf{T}}$、$\boldsymbol{r}_y=(0,1,\psi_y)^{\mathsf{T}}$，按叉积公式计算得

$$\begin{aligned}\boldsymbol{r}_x\times\boldsymbol{r}_y&=(0\cdot\psi_y-\psi_x\cdot 1,\ \psi_x\cdot 0-1\cdot\psi_y,\ 1\cdot 1-0\cdot 0)^{\mathsf{T}}\\&=(-\psi_x,-\psi_y,1)^{\mathsf{T}}.\end{aligned}$$

叉积的第三分量恒为 1，所以图像参数化处处正则；前两个坐标就是参数本身，所以单次覆盖也自动成立。于是对曲面可积的 h 有

$$\int_S h\,\mathrm{d}S=\iint_D h(x,y,\psi(x,y))\sqrt{1+\psi_x^2+\psi_y^2}\,\mathrm{d}x\,\mathrm{d}y.$$

根号的几何意义如下。记 γ 为法向 $(-\psi_x,-\psi_y,1)^{\mathsf T}$ 与 z 轴的夹角，则 $\cos\gamma = 1/\sqrt{1+\psi_x^2+\psi_y^2}$。一块与水平面成角 γ 的小平面片，竖直投影到 xy 平面上时面积缩小为原来的 $\cos\gamma$ 倍；反过来，由投影面积 $\mathrm{d}x\,\mathrm{d}y$ 恢复实际面积，就要除以 $\cos\gamma$，即乘上这个根号。曲面越陡，根号越大。例如 $z = ax+by+c$ 在单位圆盘上方的部分，根号处处等于 $\sqrt{1+a^2+b^2}$，面积为 $\pi\sqrt{1+a^2+b^2}$；$a=b=0$ 时它就是水平圆盘的面积 π。若曲面不能单值地投影到同一坐标平面，例如整张球面在每个 (x,y) 上方有两点，则需换参数化或分片。

半径 $R>0$ 的球面可以取参数

$$\boldsymbol{r}(\varphi,\theta) = (R\sin\varphi\cos\theta,\, R\sin\varphi\sin\theta,\, R\cos\varphi)^{\mathsf T},$$
$$0\le\varphi\le\pi,\quad 0\le\theta\le 2\pi,$$

其中 φ 是与北极方向的夹角，θ 是绕 z 轴转过的角度。求偏导得

$$\boldsymbol{r}_\varphi = (R\cos\varphi\cos\theta,\, R\cos\varphi\sin\theta,\, -R\sin\varphi)^{\mathsf T},$$
$$\boldsymbol{r}_\theta = (-R\sin\varphi\sin\theta,\, R\sin\varphi\cos\theta,\, 0)^{\mathsf T}.$$

这两个向量的内积为零，长度分别为 R 和 $R\sin\varphi$；由叉积长度公式（夹角为 $\pi/2$），叉积长度为 $R^2\sin\varphi$。这个结果也可以直接看出：φ 增加 $\Delta\varphi$ 时，点沿经线走过约 $R\Delta\varphi$；θ 增加 $\Delta\theta$ 时，点沿半径为 $R\sin\varphi$ 的纬线圈走过约 $R\sin\varphi\,\Delta\theta$。小片近似为以这两个长度为边的矩形。靠近两极时纬线圈变小，同样的 $\Delta\theta$ 对应的面积也变小。

在参数域内部 $0<\varphi<\pi$、$0<\theta<2\pi$ 上 $\sin\varphi>0$，参数化正则且单次覆盖；两极与经线接缝来自参数边界，面积为零，不需要单独处理。先用这个参数化求球面面积。

示例 23.9　球面的面积　对半径为 R 的球面，球坐标参数的面积放大倍数为 $J_S = R^2\sin\varphi$，被积函数连续，可以逐次积分：

$$\operatorname{area}(S) = \int_0^{2\pi}\!\!\int_0^{\pi} R^2\sin\varphi\,\mathrm{d}\varphi\,\mathrm{d}\theta = 2\pi R^2\big[-\cos\varphi\big]_0^{\pi} = 4\pi R^2.$$

求平均值时，面积权重同样不可缺少。下面以上半球面上的平均高度为例。

示例 23.10 上半球面的平均高度 取上半球面 $0 \le \varphi \le \pi/2$，高度函数 $h(\boldsymbol{x}) = z$。由 $J_S = R^2 \sin\varphi$，上半球面面积为 $2\pi R^2 \int_0^{\pi/2} \sin\varphi \,\mathrm{d}\varphi = 2\pi R^2$，而

$$\int_S z \,\mathrm{d}S = \int_0^{2\pi} \int_0^{\pi/2} R\cos\varphi \cdot R^2 \sin\varphi \,\mathrm{d}\varphi \,\mathrm{d}\theta = 2\pi R^3 \cdot \frac{1}{2} = \pi R^3,$$

所以按面积加权的平均高度为 $\pi R^3/(2\pi R^2) = R/2$。若改为在参数矩形 $[0,\pi/2]\times[0,2\pi]$ 上按参数面积平均，则得到

$$\frac{1}{(\pi/2)\cdot 2\pi} \int_0^{2\pi} \int_0^{\pi/2} R\cos\varphi \,\mathrm{d}\varphi \,\mathrm{d}\theta = \frac{2R}{\pi} \approx 0.64R.$$

两种平均不同，是因为同样大小的参数格子在北极附近只对应很小的面积：按参数平均会过多计入北极附近的高点，因而高估平均高度。面积权重 $R^2\sin\varphi$ 正是为了按实际面积而不是按参数格子求平均。

23.3 第二类曲面积分

现在回到本章开头的第二个问题：向量场穿过曲面的总量。面积只给出小片的大小；要说“穿过”，还要规定曲面的哪一侧算出发侧、哪一侧算到达侧。所以本节先讨论曲面的定向，再定义通量。

23.3.1 曲面的定向

单位法向量 在正则点，切平面有两个互相相反的单位法向量，分别指向曲面的两侧。选定其中一个，就约定：从曲面上背向它的一侧穿到它所指的一侧，算作正向穿越。参数化的叉积给出一个自然的局部选择：在 E° 上令

$$\boldsymbol{n}(\boldsymbol{r}(u,v)) = \frac{\boldsymbol{r}_u \times \boldsymbol{r}_v}{\|\boldsymbol{r}_u \times \boldsymbol{r}_v\|_2}.$$

由叉积的性质，这个向量长度为 1，并且垂直于两个参数方向，即垂直于切平面；交换 u, v 的次序会把它反转。

在斜平面片上，这个公式给出 $(-1,-1,1)^{\mathsf{T}}/\sqrt{3}$，它的第三分量为正，指向平面的上方。在球坐标参数下，直接计算可得

$$\boldsymbol{r}_\varphi \times \boldsymbol{r}_\theta = R^2 \sin\varphi\,(\sin\varphi\cos\theta, \sin\varphi\sin\theta, \cos\varphi)^{\mathsf{T}} = R\sin\varphi\,\boldsymbol{r}(\varphi,\theta).$$

在参数域内部，叉积是位置向量的正数倍，所以单位法向为 $\boldsymbol{r}/R$，指向球的外侧。参数边界上若叉积退化，例如球面的两极，就不用这个商定义法向；该部分面积为零，不影响通量积分。

定向与可定向性　只在每一点分别选一个法向还不够。若相邻两点的法向分别指向曲面的两侧，“正向穿越”就没有一致的含义。直观地说，给曲面定向就是给它的一侧涂上颜色，并约定法向总是从未涂色的一侧指向涂了色的一侧。沿曲面连续移动时，法向箭头不能突然跳到另一侧。

定义 23.11　曲面的定向　在光滑曲面 S 上连续选取一个单位法向量场 $\boldsymbol{n}$，称为给曲面**定向**（orientation）。存在这种选择的曲面称为可定向曲面；$\boldsymbol{n}$ 和 $-\boldsymbol{n}$ 给出相反的定向。分片光滑曲面要求各片的选择相容：光滑接合处选择同一侧法向，折角处按整个曲面的同一侧约定，但不要求接缝上存在唯一法向。

常见曲面都可以定向。函数图像可以选第三分量为正的向上法向；球面可以选外法向 $\boldsymbol{x}/R$，此时涂色的一侧是外表面。闭曲面把空间分成内外两部分；当它围成一个规则区域时，通常选取指向区域外侧的外法向，第 24.2节的散度定理也采用这一约定。立方体表面是分片曲面，六个面各自选指向立方体外的法向，这些选择在棱处都属于外侧，因而相容。

并非所有曲面都能定向，典型的例子是 Möbius 带：把一条长纸带扭转半圈，再把两端粘在一起。一只蚂蚁从某点出发，沿纸带中线爬一圈，始终不跨过纸带边缘；回到出发位置时，它却站在出发时的背面。想只涂纸带的一面，沿中线一直涂下去，最后两面都会被涂上颜色。用参数可以把这一现象写成具体计算。

示例 23.12　Möbius 带上的法向绕行一圈后反向　取

$$\boldsymbol{r}(u,v)=\Big(\lambda\cos u,\ \lambda\sin u,\ \tfrac{v}{2}\sin\tfrac{u}{2}\Big)^{\top},\qquad \lambda=1+\tfrac{v}{2}\cos\tfrac{u}{2},$$
$$0\le u\le 2\pi,\quad -1\le v\le 1.$$

u 绕中心圆走一圈，v 在纸带的宽度方向变化；绕行一圈时宽度方向只转过半圈，所以 $\boldsymbol{r}(2\pi,v)=\boldsymbol{r}(0,-v)$，参数边界 $u=0$ 与 $u=2\pi$ 被反向粘在一起。在中线 $v=0$ 上，$\boldsymbol{r}_u=(-\sin u,\cos u,0)^{\top}$，$\boldsymbol{r}_v=\tfrac12\big(\cos\tfrac{u}{2}\cos u,\ \cos\tfrac{u}{2}\sin u,\ \sin\tfrac{u}{2}\big)^{\top}$，于是

$$\boldsymbol{N}(u)=\boldsymbol{r}_u\times\boldsymbol{r}_v=\tfrac12\Big(\cos u\sin\tfrac{u}{2},\ \sin u\sin\tfrac{u}{2},\ -\cos\tfrac{u}{2}\Big)^{\top},$$

它的长度恒为 $1/2$。$u=0$ 时它是 $\tfrac12(0,0,-1)^{\top}$，$u=2\pi$ 时它是 $\tfrac12(0,0,1)^{\top}$，而两者对应同一点 $\boldsymbol{r}(0,0)=\boldsymbol{r}(2\pi,0)=(1,0,0)^{\top}$。

假设 $\boldsymbol{n}$ 是 Möbius 带上连续的单位法向场。在中线上的点 $\boldsymbol{r}(u,0)$ 处，$\boldsymbol{n}$ 与 $2\boldsymbol{N}(u)$ 都是单位法向，只能相等或相反。记

$$\varepsilon(u) = 2\boldsymbol{n}(\boldsymbol{r}(u,0))^{\top}\boldsymbol{N}(u) \in \{1,-1\}.$$

ε 在 $[0,2\pi]$ 上连续且只取 ± 1，所以是常数。但 $\boldsymbol{n}(\boldsymbol{r}(0,0)) = \boldsymbol{n}(\boldsymbol{r}(2\pi,0))$ 而 $\boldsymbol{N}(2\pi) = -\boldsymbol{N}(0)$，从而 $\varepsilon(2\pi) = -\varepsilon(0)$，矛盾。因此 Möbius 带上不存在连续的单位法向场。

Möbius 带的面积仍可按面积计算，第一类积分也有定义，因为它们不使用法向。但“水从哪一侧流到哪一侧”在 Möbius 带上没有全局一致的含义，所以这里按全局定向定义的通量不适用于它。

23.3.2 积分的定义和可积性

通量积分 先看最简单的情形。设水以恒定速度 $\boldsymbol{v}$ 流动，一块面积为 A 的平面网放在水中，选定单位法向 $\boldsymbol{n}$。在时间 Δt 内，恰好贴在网面上的水滴各自移动 $\boldsymbol{v}\Delta t$，这段时间内穿过网的水因此充满一个斜柱体：底面就是这块网，侧棱是向量 $\boldsymbol{v}\Delta t$。斜柱体的体积等于底面积乘高，高是侧棱在 $\boldsymbol{n}$ 方向上投影的长度 $|\boldsymbol{v}^{\top}\boldsymbol{n}|\Delta t$。给这个体积加上符号，沿 $\boldsymbol{n}$ 方向穿过记为正，就得到单位时间内沿 $\boldsymbol{n}$ 方向穿过网的水量

$$\frac{A\,(\boldsymbol{v}^{\top}\boldsymbol{n})\Delta t}{\Delta t} = (\boldsymbol{v}^{\top}\boldsymbol{n})\,A.$$

这个公式区分了三种情形。水流平行于网面时，$\boldsymbol{v}^{\top}\boldsymbol{n} = 0$，斜柱体被压扁成没有体积的薄片：水沿着网面滑过，没有水穿过网。水流沿 $\boldsymbol{n}$ 方向垂直于网面时，$\boldsymbol{v}^{\top}\boldsymbol{n} = \|\boldsymbol{v}\|_2$，同样流速下穿过的水最多。水逆着 $\boldsymbol{n}$ 流动时，$\boldsymbol{v}^{\top}\boldsymbol{n} < 0$，结果为负，表示水沿 $-\boldsymbol{n}$ 方向穿过；把法向换成 $-\boldsymbol{n}$，同一股水流的结果就变号。总之，只有速度的法向分量 $\boldsymbol{v}^{\top}\boldsymbol{n}$ 起作用，切向分量对穿过的水量没有贡献。

下面用一块倾斜的正方形核对这个公式，并比较竖直流与沿着正方形的流。

示例 23.13 竖直流与切向流穿过倾斜正方形 设 $0 \le \alpha \le \pi/2$，倾斜的单位正方形为

$$\boldsymbol{r}(u,v) = (u\cos\alpha,\ v,\ u\sin\alpha)^{\top}$$
$$(u,v) \in [0,1]^2,$$

它与水平面的夹角为 α。由 $\boldsymbol{r}_u = (\cos\alpha, 0, \sin\alpha)^{\top}$ 和 $\boldsymbol{r}_v = (0,1,0)^{\top}$，计算得 $\boldsymbol{r}_u \times \boldsymbol{r}_v = (-\sin\alpha, 0, \cos\alpha)^{\top}$。它的长度为 1，所以这块面的面积为 1，单位法向为 $\boldsymbol{n} = (-\sin\alpha, 0, \cos\alpha)^{\top}$，其第三分量非负。先看竖直向上的恒定流 $\boldsymbol{F} = (0,0,c)^{\top}$。它的法向分量为 $\boldsymbol{F}^{\top}\boldsymbol{n} = c\cos\alpha$，按平面网的公式，通量为 $(\boldsymbol{F}^{\top}\boldsymbol{n}) \cdot 1 = c\cos\alpha$。例如 $c = 2$、$\alpha = 60^{\circ}$ 时通量为 1，只是水平放置（$\alpha = 0$）时通量 2 的一半：正方形越倾斜，迎着水流的部分越少。

再看沿正方形本身方向的流 $\boldsymbol{F} = (\cos\alpha, 0, \sin\alpha)^{\top} = \boldsymbol{r}_u$。这时 $\boldsymbol{F}^{\top}\boldsymbol{n} = -\sin\alpha\cos\alpha + \sin\alpha\cos\alpha = 0$，水只沿着面滑过，通量为零。

竖直流的通量 $c\cos\alpha$ 也等于流速 c 乘这块面在水平面上的投影面积：正方形投影为矩形 $[0,\cos\alpha]\times[0,1]$，面积为 $\cos\alpha$。所以对竖直落下的雨，倾斜屋顶接到的雨量只取决于屋顶的水平投影。切向流的结果则说明，沿曲面流动的场不穿过曲面。

对弯曲的曲面和随位置变化的场，把曲面分成小片 S_j，在片内取点 $\boldsymbol{x}_j$。每片近似为平面，场在片内近似为常向量 $\boldsymbol{F}(\boldsymbol{x}_j)$，所以由平面网的公式，这一片的通量约为 $\boldsymbol{F}(\boldsymbol{x}_j)^{\top}\boldsymbol{n}(\boldsymbol{x}_j)\ \mathrm{area}(S_j)$。各片相加并让分割变细，得到标量函数 $\boldsymbol{F}^{\top}\boldsymbol{n}$ 对面积的积分。$\boldsymbol{F}$ 不必是流速：电场的通量、热流密度的通量都按同样方式定义，分别描述电场穿过曲面的通量与单位时间穿过的热量。

定义 23.14　第二类曲面积分　设可定向曲面 S 已选定单位法向 $\boldsymbol{n}$，向量场 $\boldsymbol{F} : S \to \mathbb{R}^3$ 连续。定义**第二类曲面积分**（flux integral），也称通量积分，为

$$\int_S \boldsymbol{F}^{\top}\boldsymbol{n}\,\mathrm{d}S = \iint_E \boldsymbol{F}(\boldsymbol{r}(u,v))^{\top}(\boldsymbol{r}_u \times \boldsymbol{r}_v)\,\mathrm{d}u\,\mathrm{d}v, \tag{23.2}$$

其中参数化的叉积方向须与所选 $\boldsymbol{n}$ 一致；若方向相反，右端需乘 -1。分片曲面的通量按相容定向逐片相加。

式 (23.2)右端没有出现叉积的长度，因为单位法向的分母与面积元中的长度恰好抵消：

$$\boldsymbol{n}\,\mathrm{d}S = \frac{\boldsymbol{r}_u \times \boldsymbol{r}_v}{\|\boldsymbol{r}_u \times \boldsymbol{r}_v\|_2}\,\|\boldsymbol{r}_u \times \boldsymbol{r}_v\|_2\,\mathrm{d}u\,\mathrm{d}v = (\boldsymbol{r}_u \times \boldsymbol{r}_v)\,\mathrm{d}u\,\mathrm{d}v.$$

向量 $(\boldsymbol{r}_u \times \boldsymbol{r}_v)\,\mathrm{d}u\,\mathrm{d}v$ 同时记录了小片的面积（它的长度）和朝向（它的方向），称为有向面积元。计算通量时只需把场与有向面积元作内积，不必先求单位法向。

通量为正，表示沿所选法向穿过的量多于逆法向穿过的量；为负则相反。曲面上不同部分的贡献可以正负抵消，所以通量是净穿过量。通

量是一个标量，不能与把向量场三个分量分别作面积积分所得的向量 $\left(\int_S P\,\mathrm{d}S, \int_S Q\,\mathrm{d}S, \int_S R\,\mathrm{d}S\right)^{\mathsf{T}}$ 混为一谈：后者不使用法向，也不随定向改变。

若 $\boldsymbol{F} = (P, Q, R)^{\mathsf{T}}$，常把有向面积元的三个分量记为

$$\boldsymbol{n}\,\mathrm{d}S = (\mathrm{d}y\,\mathrm{d}z, \mathrm{d}z\,\mathrm{d}x, \mathrm{d}x\,\mathrm{d}y)^{\mathsf{T}},$$

从而把通量写为 $\int_S P\,\mathrm{d}y\,\mathrm{d}z + Q\,\mathrm{d}z\,\mathrm{d}x + R\,\mathrm{d}x\,\mathrm{d}y$。

每个分量是小片在相应坐标平面上的有向投影面积。以第三分量 $n_3\,\mathrm{d}S$ 为例：记 γ 为法向与 z 轴的夹角，小片投影到 xy 平面时面积乘 $|\cos\gamma| = |n_3|$，n_3 的符号则记录法向朝上还是朝下。示例 23.13中倾斜正方形的 $\mathrm{d}x\,\mathrm{d}y$ 分量为 $\cos\alpha\,\mathrm{d}u\,\mathrm{d}v$，正是它的水平投影面积。因此 $R\,\mathrm{d}x\,\mathrm{d}y$ 累计的是场的 z 分量穿过水平投影的量，另外两项同理；这些记号中的 $\mathrm{d}x\,\mathrm{d}y$ 带有符号，不同于区域积分中的面积元。

图 23.2在一个法向截面内分解场值，说明通量只累计哪一部分。

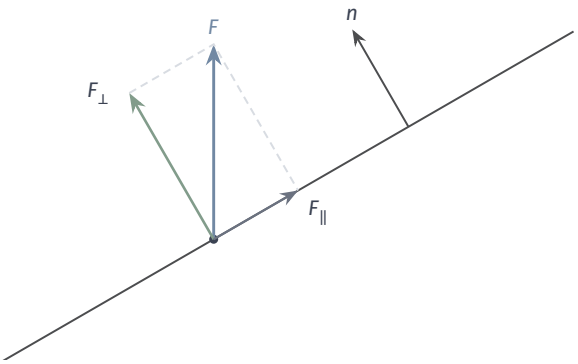


图 23.2　黑斜线表示局部切平面的一个截面，n 为所选单位法向。向量 F 分为 $F_\perp = (F^{\mathsf{T}}n)n$ 与切向部分 $F_\parallel$；通量使用有符号标量 $F^{\mathsf{T}}n$ 乘面积，切向部分不贡献。将 n 改为 $-n$ 时标量分量变号，但投影向量 $F_\perp$ 不变，这与直接把场反向不同。

连续向量场在紧曲面上有界，参数化的有向面积元也连续，所以每片上的通量都存在。

23.3.3 积分的性质

以下运算都在同一曲面、同一法向约定下进行，向量场都假设连续。通量是标量函数 $\boldsymbol{F}^{\mathsf{T}}\boldsymbol{n}$ 的面积积分，所以线性和可加性直接沿用第一类积分的性质；与方向有关的法向反转和重参数化需要单独说明。

线性 向量场相加或数乘以后,法向分量也相应地相加或数乘:$(\boldsymbol{F}+\boldsymbol{G})^{\top}\boldsymbol{n} = \boldsymbol{F}^{\top}\boldsymbol{n} + \boldsymbol{G}^{\top}\boldsymbol{n}$,$(c\boldsymbol{F})^{\top}\boldsymbol{n} = c(\boldsymbol{F}^{\top}\boldsymbol{n})$。因此

$$\int_S (\boldsymbol{F}+\boldsymbol{G})^{\top}\boldsymbol{n}\,\mathrm{d}S = \int_S \boldsymbol{F}^{\top}\boldsymbol{n}\,\mathrm{d}S + \int_S \boldsymbol{G}^{\top}\boldsymbol{n}\,\mathrm{d}S,$$
$$\int_S (c\boldsymbol{F})^{\top}\boldsymbol{n}\,\mathrm{d}S = c\int_S \boldsymbol{F}^{\top}\boldsymbol{n}\,\mathrm{d}S.$$

两股水流叠加后穿过网的水量，等于两股水流分别穿过的水量之和；流速加倍，穿过的水量也加倍。这里缩放的是场，曲面的法向约定保持不变。

曲面分割的可加性 将 S 分为内部不重叠的有限片 $S_1,\dots,S_N$，并在每片采用原定向的限制，则

$$\int_S \boldsymbol{F}^{\top}\boldsymbol{n}\,\mathrm{d}S = \sum_{j=1}^{N}\int_{S_j} \boldsymbol{F}^{\top}\boldsymbol{n}\,\mathrm{d}S.$$

零面积的接缝不贡献积分。关键在于每片沿用原来的法向：若某片单独反转法向，这一片计入的是反方向的穿越量，加起来就不再是整张曲面的通量。

法向反转 在场和曲面不变时，把 $\boldsymbol{n}$ 换成 $-\boldsymbol{n}$ 会使通量变号：

$$\int_S \boldsymbol{F}^{\top}(-\boldsymbol{n})\,\mathrm{d}S = -\int_S \boldsymbol{F}^{\top}\boldsymbol{n}\,\mathrm{d}S.$$

水流本身没有变，变的只是计数方向。例如原法向朝上时，从下往上的穿越原来记为正，现在记为负。第一类积分不使用法向，换定向不改变结果，这是两类积分的区别。

重参数化 更换参数时，所选的几何法向保持不变。由定理 23.7，新参数的叉积等于原叉积乘 $\det \boldsymbol{J}_T$，而二维换元公式使用的是 $|\det \boldsymbol{J}_T|$。若 $\det \boldsymbol{J}_T > 0$，两者相同，式 (23.2) 右端不变；若 $\det \boldsymbol{J}_T < 0$，例如交换两个参数，新叉积指向相反一侧，按定义中“方向相反时乘 -1”的约定校正后，结果仍不变。因此，固定曲面定向并完成这一校正后，通量只依赖曲面、定向和场，与参数的选择无关。

23.3.4 积分的计算

计算通量分三步：先确定要用哪一侧的法向，再选一个叉积指向该侧的参数化（若指向相反，就在结果前加负号），最后在参数域上累计 $\boldsymbol{F}$ 与有向面积元的内积。

对于图像曲面 $z=\psi(x,y)$，第一类积分的计算中已经求出叉积

$$\boldsymbol{r}_x\times\boldsymbol{r}_y=(-\psi_x,-\psi_y,1)^{\top},$$

它的第三分量为正，指向上方。因此取向上法向时，对 $\boldsymbol{F}=(P,Q,R)^{\top}$ 有

$$\int_S \boldsymbol{F}^{\top}\boldsymbol{n}\,\mathrm{d}S=\iint_D(-P\psi_x-Q\psi_y+R)(x,y,\psi(x,y))\,\mathrm{d}x\,\mathrm{d}y.$$

取向下法向则在右侧加负号。这一式直接使用有向面积元，叉积的长度已经与单位法向的分母抵消，不能再额外乘一次 $\sqrt{1+\psi_x^2+\psi_y^2}$。

斜平面片是 $\psi(x,y)=x+y$ 在单位正方形上的图像，可以用它核对通量与投影面积的关系。

示例 23.15　斜平面片上的竖直通量　取斜平面片 $\boldsymbol{r}(u,v)=(u,v,u+v)^{\top}$、$E=[0,1]^2$ 和向上单位法向 $(-1,-1,1)^{\top}/\sqrt{3}$。对竖直单位场 $\boldsymbol{F}=(0,0,1)^{\top}$，用有向面积元计算，场与参数叉积 $(-1,-1,1)^{\top}$ 的内积为 1，故

$$\int_S \boldsymbol{F}^{\top}\boldsymbol{n}\,\mathrm{d}S=\int_0^1\int_0^1 1\,\mathrm{d}u\,\mathrm{d}v=1.$$

也可以把面积和法向分量分开计算：这块面的面积为 $\sqrt{3}$（示例 23.5），场的法向分量处处为 $\boldsymbol{F}^{\top}\boldsymbol{n}=1/\sqrt{3}$，两者相乘仍为 1。这个值恰好是斜平面片在 xy 平面上的投影面积。

同样地，平面 $z=ax+by+c$ 在单位圆盘 D 上方的部分对该场的向上通量为 $\iint_D 1\,\mathrm{d}x\,\mathrm{d}y=\pi$，等于水平投影面积；它的实际面积则为 $\pi\sqrt{1+a^2+b^2}$。这与示例 23.13中倾斜屋顶接雨的结果一致：竖直的流只“看见”曲面的水平投影。

对半径为 R 的球面，讨论单位法向量时已算出 (φ,θ) 次序的参数叉积为 $R\sin\varphi\,\boldsymbol{r}$，它在参数域内部指向外侧。下面三个例子都取外法向，依次计算径向场、点源场和恒定场的通量。

示例 23.16　径向场穿过球面　令 $\boldsymbol{F}(\boldsymbol{x})=\boldsymbol{x}/R$。在球面上 $\boldsymbol{F}$ 恰等于外单位法向，$\boldsymbol{F}^{\top}\boldsymbol{n}=1$，由示例 23.9，

$$\int_S \boldsymbol{F}^{\top}\boldsymbol{n}\,\mathrm{d}S=\int_S 1\,\mathrm{d}S=4\pi R^2.$$

取内法向时通量为 $-4\pi R^2$。

这次外向通量与面积相等，是因为法向分量处处为 1。一般情形下 $|\boldsymbol{F}^{\top}\boldsymbol{n}|\le\|\boldsymbol{F}\|_2$，通量的绝对值不超过场的大小对面积的积分；场的方向偏离法向时，只有法向分量计入通量。

接下来的两个例子形成对比：一个场由原点处的点源发出，另一个场在空间中处处相同。

示例 23.17　点源场的通量与半径无关　令 $\boldsymbol{F}(\boldsymbol{x}) = \boldsymbol{x}/\|\boldsymbol{x}\|_2^3$（$\boldsymbol{x} \neq \boldsymbol{0}$），$S$ 是以原点为中心、半径为 R 的球面，外法向为 $\boldsymbol{n} = \boldsymbol{x}/R$。$\boldsymbol{F}$ 在不含原点的球面上连续，因而法向分量可积。在 S 上 $\|\boldsymbol{x}\|_2 = R$，故

$$\boldsymbol{F}^{\top}\boldsymbol{n} = \frac{\boldsymbol{x}^{\top}\boldsymbol{x}}{R^3 \cdot R} = \frac{1}{R^2},$$

外向通量为 $(1/R^2) \cdot 4\pi R^2 = 4\pi$。

球面越大，场越弱，但面积增大的倍数恰好抵消场的减弱，所以通量不随 R 改变：以点源为中心的球面无论多大，测得的点源单位时间放出的总量都一样。

示例 23.18　恒定场穿过球面的净通量为零　令 $\boldsymbol{F} = (0,0,1)^{\top}$。由 $\boldsymbol{r}_{\varphi} \times \boldsymbol{r}_{\theta} = R\sin\varphi\,\boldsymbol{r}$，被积函数为 $\boldsymbol{F}^{\top}(\boldsymbol{r}_{\varphi} \times \boldsymbol{r}_{\theta}) = R\sin\varphi \cdot R\cos\varphi = R^2 \sin\varphi\cos\varphi$，于是

$$\int_S \boldsymbol{F}^{\top}\boldsymbol{n}\,\mathrm{d}S = \int_0^{2\pi}\int_0^{\pi} R^2 \sin\varphi\cos\varphi\,\mathrm{d}\varphi\,\mathrm{d}\theta = 0.$$

分开计算，上半球面 $0 \le \varphi \le \pi/2$ 的外向通量为

$$2\pi R^2 \int_0^{\pi/2} \sin\varphi\cos\varphi\,\mathrm{d}\varphi = \pi R^2,$$

下半球面 $\pi/2 \le \varphi \le \pi$ 的外向通量为 $-\pi R^2$。

在恒定场中，水从下半球面流入球内，又从上半球面等量流出；球内既不产生也不吸收水，所以闭曲面的净通量为零。包围点源的球面则有正的净通量。可见闭曲面的净通量反映它所围区域内部的源与汇。第 24.2节将用区域内部的散度累计来计算闭曲面的通量，并核对这里的几个结果。

23.4　本章小结

曲面积分先要解决面积的度量。正则参数曲面片用两个参数标记曲面上的点，两条切向量 $\boldsymbol{r}_u, \boldsymbol{r}_v$ 张成切平面；参数小矩形近似映为以 $\boldsymbol{r}_u\Delta u, \boldsymbol{r}_v\Delta v$ 为边的平行四边形，面积放大倍数是叉积长度 $\|\boldsymbol{r}_u \times \boldsymbol{r}_v\|_2$，也等于两切向量 Gram 行列式的平方根。面积直接定义为这个倍数的参数积分，内接三角形的上确界在曲面上会失败。正则性排除被压扁的参数化，单次覆盖排除重复计数；合法的换参数使叉积乘上 $\det \boldsymbol{J}_T$，面积因而不变。参数边界上

的接缝或退化点（例如球坐标的两极）只是参数的奇异，不是曲面本身的奇异，面积为零，不影响积分。

第一类曲面积分按面积累计标量面密度，权重 $\mathrm{d}S$ 非负，结果与参数化和曲面的定向都无关。按面积平均与按参数平均不同：上半球面的平均高度按面积是 $R/2$，按经纬度格子是 $2R/\pi$。函数图像的面积元是 $\sqrt{1+\psi_x^2+\psi_y^2}\,\mathrm{d}x\,\mathrm{d}y$，球面的是 $R^2\sin\varphi\,\mathrm{d}\varphi\,\mathrm{d}\theta$。

第二类曲面积分累计向量场的法向分量 $\boldsymbol{F}^{\mathsf{T}}\boldsymbol{n}$，先要给曲面连续地选定一侧的单位法向；Möbius 带不存在这样的选择，因而没有全局的通量。参数公式使用有向面积元 $(\boldsymbol{r}_u\times\boldsymbol{r}_v)\,\mathrm{d}u\,\mathrm{d}v$，叉积的方向须与所选法向一致，否则乘以 -1；交换参数次序会反转叉积。法向反转使通量变号，分片曲面要求各片法向相容，封闭曲面通常取外法向。

几个球面例子显示了通量的含义：点源场的外向通量与半径无关，恒定场穿过闭球面的净通量为零。闭曲面的净通量反映所围区域内部的源与汇，这正是下一章 Gauss 公式要精确表达的关系；有边界的定向曲面则通过诱导方向与边界环流联系，由 Stokes 公式表达。

第 24 章

积分定理

一元微积分基本定理说，f' 在区间上的积分等于 f 在两个端点上的值之差：内部各点的变化率累计起来，只剩下边界上的信息。前两章分别在路径和曲面上累计了向量场的切向分量与法向分量，得到环流与通量。本章要回答：对平面区域、空间区域和有边界的曲面，内部的哪种导数累计起来恰好等于边界上的环流或通量；这样的等式在什么条件下成立，能用来做什么。

第一节先回答“内部的哪种导数”。把向量场看作流体的速度场，散度是一点附近单位体积的净流出，旋度沿某个方向的分量是垂直于该方向的单位面积环流；两者都由收缩小立方体、小正方形上的通量和环流求极限得到。Laplace 算子是梯度的散度，比较函数在一点的值与周围平均值，并与梯度、散度、旋度之间的恒等式一起，为后面的分部积分准备材料。

第二节把局部关系拼成整体关系。把对象切成小块，每块上导数乘大小近似等于边界上的累计；相邻小块的公共边界被沿相反方向各算一次而抵消，只剩外边界。按这一机制依次得到平面区域上的 Green 公式、空间区域上的 Gauss 公式和有边界曲面上的 Stokes 公式，再由 Gauss 公式推出多元分部积分与 Green 恒等式。

使用这些公式时要分清几种条件：边界取正向、外法向还是由曲面法向诱导的方向；向量场是否在整个积分对象附近连续可微；边界项能否因边界条件而消失。本章使用第 21章的区域积分与累次积分，第 22章的环流与势函数，第 23章的通量与定向，以及第 17章的 Jacobian、Hessian 与混合偏导数的交换。

24.1 局部微分算子

欧氏坐标下，标量函数的梯度就是一阶偏导数排成的列向量（式 (17.4)）。对向量场，各分量一阶偏导数的适当组合也给出有几何含义的量。设 $\boldsymbol{F}$ 是开集 U 上的向量场，不妨把它想成流体的速度场：$\boldsymbol{F}(\boldsymbol{x})$ 是流体在位置 $\boldsymbol{x}$ 处的速度。

对这样的场有两个自然的局部问题：在一点附近，流体是净流出还是净流入；流体是否绕这一点打转。两个问题的答案都由 $\boldsymbol{F}$ 各分量的一阶偏导数决定，只是用到的组合不同：回答前者的是散度，回答后者的是旋度。

最后的 Laplace 算子作用于标量函数，比较函数在一点的值与周围平均值的差别。这三个算子都是下一节积分公式中的内部量。

24.1.1 散度与局部通量

小立方体的净流出 设 $\boldsymbol{F}=(F_1,F_2,F_3)^{\mathsf{T}}$ 是三维流体的速度场。由第 23章，单位时间穿过面积为 ΔS、单位法向为 $\boldsymbol{n}$ 的一小片曲面的流体体积约为 $(\boldsymbol{F}^{\mathsf{T}}\boldsymbol{n})\Delta S$。现在以点 $\boldsymbol{a}$ 为中心取边长为 h 的小立方体，各面与坐标平面平行，估计单位时间从它流出的净体积。

先看与 x 轴垂直的两张面。右面 $x=a_1+h/2$ 的外法向是 $\boldsymbol{e}_1$，场在这张面上的法向分量是 F_1；用面中心的值代表整张面，流出量约为 $F_1(\boldsymbol{a}+\frac{h}{2}\boldsymbol{e}_1)h^2$。左面 $x=a_1-h/2$ 的外法向是 $-\boldsymbol{e}_1$，流出量约为 $-F_1(\boldsymbol{a}-\frac{h}{2}\boldsymbol{e}_1)h^2$；$F_1>0$ 时这个量为负，表示沿 x 正方向的流动在左面是流入。两面合计为

$$\Big[F_1\big(\boldsymbol{a}+\tfrac{h}{2}\boldsymbol{e}_1\big)-F_1\big(\boldsymbol{a}-\tfrac{h}{2}\boldsymbol{e}_1\big)\Big]h^2\approx \partial_1F_1(\boldsymbol{a})\,h\cdot h^2,$$

这里用偏导数乘距离 h 近似 F_1 在两张面中心之间的差。若 F_1 沿 x 方向增大，右面流出的比左面流入的多，这对面贡献正的净流出；若 F_1 沿 x 方向不变，流入与流出恰好相等。

另外两对面同样分别给出约 $\partial_2F_2(\boldsymbol{a})h^3$ 和 $\partial_3F_3(\boldsymbol{a})h^3$。六张面合计后除以体积 h^3，得到

$$\frac{\text{小立方体的净流出}}{\text{小立方体的体积}}\approx \partial_1F_1(\boldsymbol{a})+\partial_2F_2(\boldsymbol{a})+\partial_3F_3(\boldsymbol{a}).$$

这个近似可以变成极限。$\boldsymbol{F}$ 连续可微时，可以在整个小立方体上把它展开为 $\boldsymbol{F}(\boldsymbol{a})+D\boldsymbol{F}(\boldsymbol{a})(\boldsymbol{x}-\boldsymbol{a})+o(h)$。每张面的面积为 h^2，所以余项对六张面通量的总贡献是 $o(h^3)$。常数项在相对的两面上抵消，线性项给出上面的三个偏导数。除以 h^3 再令 $h\to 0$，净流出与体积之比的极限就是上式右侧。这一步只用到局部展开，不需要整个区域上的 Gauss 公式。右侧的偏导数之和称为散度。

定义 24.1　散度 设 $U\subseteq\mathbb{R}^d$ 为开集，$\boldsymbol{F}=(F_1,\dots,F_d)^{\mathsf{T}}:U\to\mathbb{R}^d$ 的各分量一阶偏导数存在。$\boldsymbol{F}$ 的**散度**（divergence）是标量函数

$$\operatorname{div}\boldsymbol{F}=\nabla\cdot\boldsymbol{F}=\sum_{j=1}^{d}\partial_jF_j.$$

当 $\boldsymbol{F}$ 可微时，这个和也等于 Jacobian 矩阵 $D\boldsymbol{F}$ 的迹。它只累计对应坐标方向的变化率；非对角偏导数不直接进入净流出率。

源的强度 由小立方体上的推导，散度是单位体积的净流出率，可以理解为一点处源的强度。$\operatorname{div}\boldsymbol{F}(\boldsymbol{a}) > 0$ 表示 $\boldsymbol{a}$ 附近像有一个源，流体在这里产生并向外流走；$\operatorname{div}\boldsymbol{F}(\boldsymbol{a}) < 0$ 表示这里像一个汇，流入的多于流出的；散度为零表示流入与流出平衡。若流体不可压缩，内部又没有注入或抽出流体的源和汇，则每个小体积的流入量都等于流出量，速度场的散度处处为零。

下面三个场分别对应均匀膨胀、绕轴转动和整体平移，可以用来检验这一解释。

示例 24.2 径向场、旋转场与常场的散度 三维径向场 $\boldsymbol{F}(x,y,z) = (x,y,z)^{\mathsf{T}}$ 满足 $\partial_x F_1 = \partial_y F_2 = \partial_z F_3 = 1$，所以 $\operatorname{div}\boldsymbol{F} = 1+1+1 = 3$：流体从各处均匀地向外膨胀，每单位体积每单位时间多出 3 个单位体积的流体。

旋转场 $\boldsymbol{G}(x,y,z) = (-y,x,0)^{\mathsf{T}}$ 的第一分量不含 x，第二分量不含 y，第三分量为零，所以 $\operatorname{div}\boldsymbol{G} = 0+0+0 = 0$：流体绕 z 轴转动，任何小立方体流入多少就流出多少。

常场 $\boldsymbol{H} = (1,0,0)^{\mathsf{T}}$ 的各分量都是常数，散度同样为 0：流体整体平移，每个小立方体从左面流入的量都从右面流出。

旋转场和常场都不是零场，散度却都为零。散度为零只表示局部净流出率为零，不表示向量场为零。

二维场 $(P,Q)^{\mathsf{T}}$ 的散度相应为 $P_x + Q_y$，它是小正方形四条边上的净流出除以面积所得的极限；定理 24.13的平面通量公式使用这一标量函数。

24.1.2 旋度与局部环流

小正方形上的环流 净流出不能描述绕一点的旋转。旋转场 $\boldsymbol{G} = (-y,x,0)^{\mathsf{T}}$ 的散度为零，但在水平平面内沿以 z 轴上一点为圆心的圆周逆时针走一圈，场始终与行进方向相同，环流不为零。度量一点附近的旋转，要用小闭路径上的环流。先在平面上计算小正方形边界的环流。

设平面场为 $(P,Q)^{\mathsf{T}}$，以 $\boldsymbol{a}$ 为中心取边长为 h 的正方形，沿逆时针方向走一圈。

下边从左向右，切向分量是 P，贡献约 $P(\boldsymbol{a} - \frac{h}{2}\boldsymbol{e}_2)h$；上边从右向左，贡献约 $-P(\boldsymbol{a} + \frac{h}{2}\boldsymbol{e}_2)h$；两者合计约 $-\partial_y P(\boldsymbol{a})h^2$。右边从下向上，贡献约

$Q(\boldsymbol{a}+\frac{h}{2}\boldsymbol{e}_1)h$；左边从上向下，贡献约 $-Q(\boldsymbol{a}-\frac{h}{2}\boldsymbol{e}_1)h$；两者合计约 $\partial_x Q(\boldsymbol{a})h^2$。四边相加后除以面积 h^2，得到

$$\frac{\text{小正方形边界的逆时针环流}}{\text{小正方形的面积}} \approx \partial_x Q(\boldsymbol{a}) - \partial_y P(\boldsymbol{a}).$$

两项的符号可以这样理解。若 Q 沿 x 方向增大，右边向上的流速比左边大，这一对边推动逆时针转动；若 P 沿 y 方向增大，上边向右的流速比下边大，这一对边推动顺时针转动，所以 $\partial_y P$ 带负号。

在三维空间中，小正方形可以放在分别垂直于三个坐标轴的平面里，行进方向都取从相应坐标轴正方向看的逆时针。垂直于 z 轴时，平面坐标是 (x,y)，(F_1,F_2) 相当于 (P,Q)，同样的计算给出 $\partial_x F_2 - \partial_y F_1$；垂直于 x 轴时，平面坐标的次序是 (y,z)，(F_2,F_3) 相当于 (P,Q)，得到 $\partial_y F_3 - \partial_z F_2$；垂直于 y 轴时，平面坐标的次序是 (z,x)，(F_3,F_1) 相当于 (P,Q)，得到 $\partial_z F_1 - \partial_x F_3$。这样选取坐标次序，是因为 $\boldsymbol{e}_2\times\boldsymbol{e}_3=\boldsymbol{e}_1$、$\boldsymbol{e}_3\times\boldsymbol{e}_1=\boldsymbol{e}_2$：从坐标轴正方向看，第一个平面坐标轴逆时针转过直角得到第二个。把这三个环流率按 x,y,z 轴的次序排成一个向量，就得到旋度。

定义 24.3　旋度　设 $U\subseteq\mathbb{R}^3$ 为开集，$\boldsymbol{F}=(F_1,F_2,F_3)^{\mathsf{T}}: U\to\mathbb{R}^3$ 的各分量一阶偏导数存在。$\boldsymbol{F}$ 的**旋度**（curl）是向量场

$$\operatorname{curl}\boldsymbol{F} = \nabla\times\boldsymbol{F} = \begin{pmatrix} \partial_y F_3 - \partial_z F_2 \\ \partial_z F_1 - \partial_x F_3 \\ \partial_x F_2 - \partial_y F_1 \end{pmatrix}.$$

旋转的轴与强度　坐标平面上的三个计算可以推广到任意方向。

设 $\boldsymbol{F}$ 连续可微，$\boldsymbol{n}$ 是单位向量；在过点 $\boldsymbol{a}$ 且垂直于 $\boldsymbol{n}$ 的平面内，取以 $\boldsymbol{a}$ 为中心的小正方形或小圆周，从 $\boldsymbol{n}$ 的箭头一侧看按逆时针行进。尺寸趋于零时，环流除以所围面积的极限等于 $(\operatorname{curl}\boldsymbol{F})(\boldsymbol{a})^{\mathsf{T}}\boldsymbol{n}$。$\boldsymbol{n}$ 为坐标轴方向时，这就是上面的计算；一般方向的证明放在 Stokes 公式之后。

由 Cauchy–Schwarz 不等式，$(\operatorname{curl}\boldsymbol{F})^{\mathsf{T}}\boldsymbol{n} \le \|\operatorname{curl}\boldsymbol{F}\|_2$；旋度不为零时，等号当且仅当 $\boldsymbol{n}$ 与旋度同向时成立。所以旋度的方向是局部旋转最强的转轴，其长度是旋转的强度；转向由右手定则确定：右手大拇指沿旋度方向，其余四指弯曲的方向就是转向。

一个物理图像是放进流水中的小桨轮。让桨轮的转轴沿 $\boldsymbol{n}$，水流沿轮缘推动各个叶片。桨轮是否转动、往哪边转，取决于沿轮缘的环流，也就是 $(\operatorname{curl}\boldsymbol{F})^{\mathsf{T}}\boldsymbol{n}$ 的符号；转轴与旋度平行时转得最快。这一图像帮助理解定义，但不代替上面的计算。

先用整体转动和径向膨胀检验这一图像。

示例 24.4 刚体旋转与径向膨胀的旋度 整体以角速度 ω 绕 z 轴旋转的流体，速度场为 $\boldsymbol{F} = \omega(-y, x, 0)^{\mathsf{T}}$。代入定义，前两个分量 $\partial_y F_3 - \partial_z F_2$ 与 $\partial_z F_1 - \partial_x F_3$ 都为零，第三个分量为 $\partial_x(\omega x) - \partial_y(-\omega y) = 2\omega$，所以 $\nabla \times \boldsymbol{F} = (0, 0, 2\omega)^{\mathsf{T}}$。特别地，$\omega = 1/2$ 时 $\boldsymbol{F} = (-y/2, x/2, 0)^{\mathsf{T}}$，旋度为 $(0, 0, 1)^{\mathsf{T}}$。

径向场 $(x, y, z)^{\mathsf{T}}$ 的第 i 个分量只依赖第 i 个坐标，旋度定义中的每个交叉偏导数都为零，所以旋度为零：流体只向外膨胀而不打转。

刚体旋转的旋度沿转轴，长度是角速度的两倍，与桨轮图像一致。不过，旋度与流线是否弯曲并不是一回事，下面两个场从相反的方向说明这一点。

示例 24.5 剪切流与涡旋场 剪切流 $\boldsymbol{F} = (y, 0, 0)^{\mathsf{T}}$ 的流线都是水平直线。它的偏导数中只有 $\partial_y F_1 = 1$ 不为零，所以 $\nabla \times \boldsymbol{F} = (0, 0, -1)^{\mathsf{T}}$。物理上，上方的水比下方的水向右流得快，桨轮的上缘被推得更多，从 z 轴正方向看桨轮顺时针转动，与第三分量为负一致。

再看平面上沿同心圆流动的场。

设流体在每个以原点为圆心的圆周上逆时针流动，半径为 r 的圆周上速率为 $s(r) > 0$，其中 s 可微，即

$$(P, Q)^{\mathsf{T}} = g(r)\,(-y, x)^{\mathsf{T}}$$

$$g(r) = \frac{s(r)}{r}$$

$$r = \sqrt{x^2 + y^2} > 0.$$

由 $\partial_x r = x/r$、$\partial_y r = y/r$，有 $Q_x = g(r) + g'(r)x^2/r$、$P_y = -g(r) - g'(r)y^2/r$，所以

$$Q_x - P_y = 2g(r) + r g'(r) = \frac{s(r)}{r} + s'(r).$$

第一项 $s(r)/r$ 来自流线的弯曲，第二项 $s'(r)$ 来自不同半径上流速的差别。刚体旋转 $s(r) = \omega r$ 时两项都等于 ω，合计 2ω，与前例一致。第 22.4节穿孔平面上的涡旋场 $(-y, x)^{\mathsf{T}}/(x^2 + y^2)$ 对应 $s(r) = 1/r$，两项分别为 $1/r^2$ 与 $-1/r^2$，所以在原点以外 $Q_x - P_y = 0$。

剪切流的流线是直线，旋度却不为零；涡旋场的流线弯曲，在原点以外旋度却为零。后者的原因是：流线弯曲带来的逆时针倾向，恰好被外侧流速较慢带来的顺时针倾向抵消，所以放在原点以外的小桨轮不转。

对二维场 $(P,Q)^{\top}$，平面内需要的是标量 $Q_x - P_y$。把二维场补上为零的第三分量，写成三维场 $(P,Q,0)^{\top}$ 后，这一标量正是旋度的第三分量，也就是旋度在向上法向 $\boldsymbol{e}_3$ 上的分量。符号 $\nabla\cdot$ 和 $\nabla\times$ 表示这里定义的偏导数组合，不是两个普通数值向量的内积或叉积。

图 24.1在同一个单位圆周上分别观察净流出与切向环流，比较两种微分算子所记录的信息。

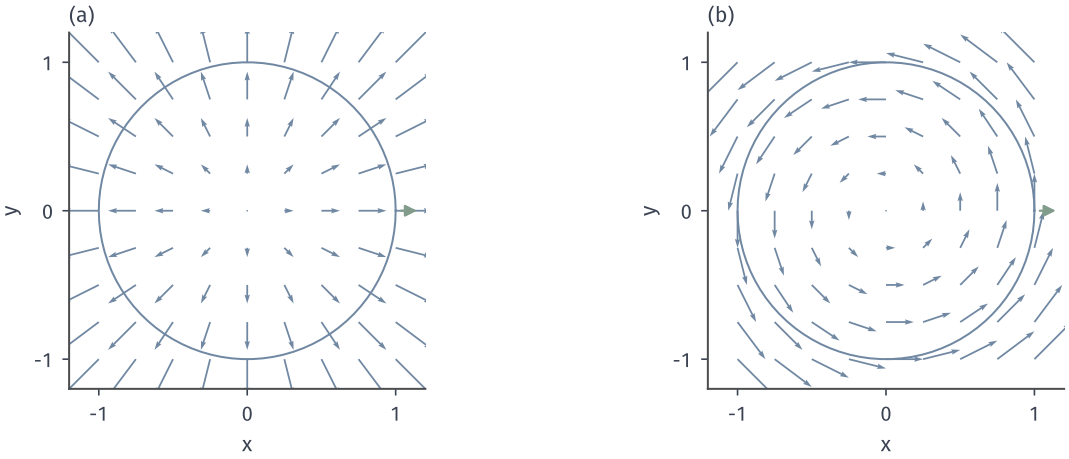


图 24.1 (a) 径向场 $(x,y)^{\top}$ 的二维散度为 2、旋转率 $Q_x - P_y = 0$，圆周外向通量为 2π、环流为零。(b) 旋转场 $(-y,x)^{\top}$ 的散度为零、旋转率为 2，通量为零、环流为 2π。绿箭头仅标记外法向；蓝色场箭头按相同常数缩放。零散度不等于零场，也不等于零环流。

24.1.3 Laplace 算子与微分恒等式

标量函数的梯度是向量场，可以对它再取散度，把各坐标方向的二阶变化相加。这一复合运算出现在多元分部积分中，也出现在描述热传导和扩散的方程中。

定义 24.6 Laplace 算子 对开集 $U \subseteq \mathbb{R}^d$ 上的二阶连续可微标量函数 v，定义Laplace 算子（Laplacian）为

$$\Delta v = \operatorname{div}(\nabla v) = \sum_{j=1}^{d} \partial_j^2 v.$$

梯度把标量函数变为向量场，散度再把向量场变为标量函数，所以 Δv 仍是标量函数；它与输入、输出都是向量场的旋度属于不同类型的运算。

从矩阵表示看，Δv 也是 Hessian 矩阵的迹。例如 $v(\boldsymbol{x}) = \|\boldsymbol{x}\|_2^2$ 的 Hessian 为 $2\boldsymbol{I}$，所以 $\Delta v = 2d$。

由混合偏导数可以交换次序，梯度、散度和旋度之间有两条恒等式。在三维开集上，若 $v \in C^2$，则

$$\operatorname{curl}(\nabla v) = \mathbf{0}.$$

例如第三分量是 $\partial_x \partial_y v - \partial_y \partial_x v = 0$，另两个分量同理。反过来，由旋度为零推出势函数存在，还要核对定义域，星形域与有孔域的区别已在第 22.4节说明。

若向量场 $\boldsymbol{F} \in C^2$，则

$$\operatorname{div}(\operatorname{curl} \boldsymbol{F}) = 0.$$

将旋度的三个分量代入散度，得到六个二阶混合偏导数，每一项都与交换求导次序后的另一项异号相消。注意对象类型：第一个等式的输入是标量函数，结果是零向量；第二个的输入是向量场，结果是数零。

与邻域平均值的差　一元情形中，$v''(a) > 0$ 表示函数在 a 附近向上弯，$v(a)$ 低于两侧邻点的平均值。多元情形可以做同样的比较。在 $\boldsymbol{a}$ 的每个坐标方向上各取前后两个邻点 $\boldsymbol{a} \pm h\boldsymbol{e}_j$，沿该坐标作二阶 Taylor 展开：

$$v(\boldsymbol{a} + h\boldsymbol{e}_j) + v(\boldsymbol{a} - h\boldsymbol{e}_j) - 2v(\boldsymbol{a}) = h^2 \partial_j^2 v(\boldsymbol{a}) + o(h^2),$$

一阶项 $\pm h\partial_j v(\boldsymbol{a})$ 在两点相加时抵消。对 $j = 1, \dots, d$ 求和，再除以邻点个数 $2d$，得到

$$\frac{1}{2d} \sum_{j=1}^{d} \bigl[v(\boldsymbol{a} + h\boldsymbol{e}_j) + v(\boldsymbol{a} - h\boldsymbol{e}_j) \bigr] - v(\boldsymbol{a}) = \frac{h^2}{2d} \Delta v(\boldsymbol{a}) + o(h^2).$$

因此，h 足够小时，$\Delta v(\boldsymbol{a}) > 0$ 表示 $v(\boldsymbol{a})$ 低于周围邻点的平均值，$\Delta v(\boldsymbol{a}) < 0$ 表示高于平均值；$\Delta v(\boldsymbol{a}) = 0$ 表示二者之差是 $o(h^2)$，在这一精度下相等。

下面用两个二次函数直接比较邻点平均值与中心值。

示例 24.7　二次函数的邻点平均　取 $v(x, y, z) = x^2 + y^2 + z^2$，则 $\Delta v = 2 + 2 + 2 = 6$。在原点，$v(\mathbf{0}) = 0$；六个邻点 $\pm h\boldsymbol{e}_j$ 上的值都是 h^2，所以邻点平均值比中心值高 h^2，恰等于 $\frac{h^2}{2d} \Delta v = \frac{h^2}{6} \cdot 6$。二次函数的 Taylor 展开没有余项，等式精确成立。

再取 $v(x, y) = x^2 - y^2$，则 $\Delta v = 2 - 2 = 0$。原点的四个邻点 $(\pm h, 0)$ 与 $(0, \pm h)$ 上的取值为 $h^2, h^2, -h^2, -h^2$，平均值恰为 $0 = v(\mathbf{0})$。

第二个函数在 x 方向向上弯、在 y 方向向下弯，两种弯曲正好抵消。Laplace 算子记录的是各坐标方向弯曲的总和，不能据此判断每个方向各自怎样弯曲。

热传导中的含义 设 $u(t,\boldsymbol{x})$ 是时刻 t 物体内位置 $\boldsymbol{x}$ 处的温度，它对 $\boldsymbol{x}$ 二阶连续可微。热量从高温处流向低温处，Fourier 热传导定律把单位时间穿过单位面积的热流写成 $\boldsymbol{q}=-k\nabla u$，其中常数 $k>0$ 为导热系数，∇ 只作用于空间变量 $\boldsymbol{x}$[1]。由散度的含义，单位体积的热量净流出率为 $\operatorname{div}\boldsymbol{q}=-k\Delta u$。没有热源时，单位体积内热量的增加率等于净流入率 $-\operatorname{div}\boldsymbol{q}=k\Delta u$；再除以单位体积的热容 $c>0$，得到温度的变化率

$$\partial_t u=\frac{k}{c}\,\Delta u,$$

这就是热传导方程。

比周围平均更冷的点满足 $\Delta u>0$，会从周围吸收热量而升温；比周围平均更热的点满足 $\Delta u<0$，会降温。温度分布因而逐渐被抹平。温度不再随时间变化时，处处有 $\Delta u=0$；由邻域平均的公式，每点的温度在上述精度下等于周围的平均。这里的 Fourier 定律是物理模型，本节只用它说明 Δ 的含义。

[1] G. Strang, E. J. Herman, *Calculus Volume 3*, OpenStax, 2016

24.2 区域与边界的积分关系

一元微积分基本定理说，若 f 在 $[a,b]$ 上连续可微，则 f' 在区间上的积分等于 $f(b)-f(a)$：区间内部各点的变化率累计起来，只剩下两个端点上的函数值。区间的边界就是这两个端点，所以 $f(b)-f(a)$ 也可以读成带符号的边界求和：右端点记正号，左端点记负号。路径积分基本定理（式 (22.3)）把同样的关系搬到路径上：梯度场沿路径的积分，等于势函数在终点与起点的值之差。

本节把“内部导数的累计等于边界上的累计”推广到平面区域、空间区域和曲面，分别得到 Green 公式、Gauss 公式和 Stokes 公式。三种推广的思路相同。先把对象切成许多小块；在每个小块上，某个导数乘小块的大小，近似等于向量场沿小块边界的累计。相邻两块的公共边界被两块各算一次，两次方向相反，相加后抵消，最后只剩下整个对象的外边界。

内部量与边界量要配对使用。沿边界的环流累计向量场的切向分量，对应的内部量是旋度；穿过边界的通量累计向量场的法向分量，对应的内部量是散度。本节先规定边界的方向，再依次给出三个公式，最后由 Gauss 公式推出多元分部积分与 Green 恒等式。经典公式的组织参考向量微积分教材[2]。

[2] G. Strang, E. J. Herman, *Calculus Volume 3*, OpenStax, 2016

边界的定向 将一个区域分成相邻小块时，公共边或公共面不属于原区域的外边界。要使这些内部贡献相消，各小块必须采用相容的方向，而且要与小块上局部计算所用的方向一致：环流按逆时针计算，通量按外法向计

算。下面依次规定平面区域边界的行进方向、区域边界的外法向，以及定向曲面边界的行进方向。

平面区域的正向边界　平面区域的边界是路径，所以先规定沿边界行进的方向。本节考虑的平面区域，边界由若干条简单闭曲线组成；简单闭曲线指除首尾相合外不自交的闭曲线。对有界平面区域，取边界方向使沿曲线前进时区域总在左侧，称为正向边界。沿单位圆逆时针行走，单位圆盘始终在左手边，所以圆盘的正向边界是逆时针方向。

有孔洞时，外边界仍是逆时针；围绕孔洞的内边界要使区域而非孔洞留在左侧，因而是顺时针。例如圆环 $1 < x^2 + y^2 < 4$ 的外圈 $r = 2$ 逆时针、内圈 $r = 1$ 顺时针，两圈边界方向相反。这个约定与小块相消的要求一致：把圆环切成许多小块，每块都按逆时针走边界，内部公共边相互抵消后，剩在孔洞边上的那些边恰好被顺时针走过。

边界由多段光滑弧组成时，按这一方向逐段相接，转角处不另加积分项。一般地，相邻平面小块各自采用正向边界时，公共边被沿相反方向走过，两个有向路径积分恰好抵消。

区域边界的外法向　通量需要的是法向，而不是边界的行进方向。空间区域的外单位法向从内部指向外部；有孔洞时，孔洞边界的外法向指向孔洞。例如球壳 $1 < \|\boldsymbol{x}\|_2 < 2$ 在外球面上的外法向背离原点，在内球面上的外法向指向原点。相邻子区域的公共面上，两侧子区域的外法向相反，所以内部通量相消。

平面区域边界上的外单位法向按同样方式规定，只是通量沿边界按弧长累计。外法向与正向边界的单位切向量 $\boldsymbol{\tau} = (\tau_1, \tau_2)^{\mathsf{T}}$ 有固定关系：区域在行进方向的左侧，外侧就在右侧，所以把 $\boldsymbol{\tau}$ 顺时针转过直角就得到外法向 $\boldsymbol{n} = (\tau_2, -\tau_1)^{\mathsf{T}}$。例如在单位圆的点 $(1,0)$ 处，逆时针的切向量是 $(0,1)^{\mathsf{T}}$，按此公式得到 $(1,0)^{\mathsf{T}}$，确实指向圆外。

定向曲面边界的诱导方向　曲面取定单位法向 $\boldsymbol{n}$ 后，边界路径的方向就不能再任意选择。边界的正向按右手约定确定：右手大拇指朝法向，其余四指弯曲的方向为正向，称为由法向诱导的方向，简称诱导方向。等价地，沿边界前进并把头朝向法向时，曲面留在左侧。面朝前进方向 $\boldsymbol{f}$、头顶朝 $\boldsymbol{u}$ 站立时，左手方向是 $\boldsymbol{u} \times \boldsymbol{f}$；用这个叉积可以核对具体例子。

下面用这个叉积核对两张以单位圆为边界的曲面，后面检验 Stokes 公式时会用到它们。

示例 24.8 向上圆盘与外向上半球面的诱导方向 对取向上法向 $\boldsymbol{e}_3$ 的单位圆盘，在边界点 $(1,0,0)$ 处取前进方向 $\boldsymbol{f}=\boldsymbol{e}_2$，左手方向为 $\boldsymbol{e}_3\times\boldsymbol{e}_2=-\boldsymbol{e}_1$，指向圆盘内部。所以诱导方向是从上方看逆时针。

对取外法向的上半单位球面，赤道上的点 $(1,0,0)$ 处外法向是 $\boldsymbol{e}_1$。同样取前进方向 $\boldsymbol{f}=\boldsymbol{e}_2$，左手方向为 $\boldsymbol{e}_1\times\boldsymbol{e}_2=\boldsymbol{e}_3$，正指向半球面所在的上方。所以它的诱导方向也是从上方看逆时针，与向上圆盘的边界方向相同。

两张曲面在边界点处的法向不同，曲面伸出的方向也不同；但二者都满足“头朝法向时曲面在左侧”，所以诱导出同一个边界方向。

翻转曲面法向，边界的诱导方向也随之翻转。分片曲面的定向相容，是指相邻曲面片在公共边上诱导出相反的行进方向。这时公共边上的路径积分相消，只留下整张曲面的真正边界。

图 24.2把相容方向的作用画出来：只有内部公共边相消，才会只剩下整个对象的外边界。

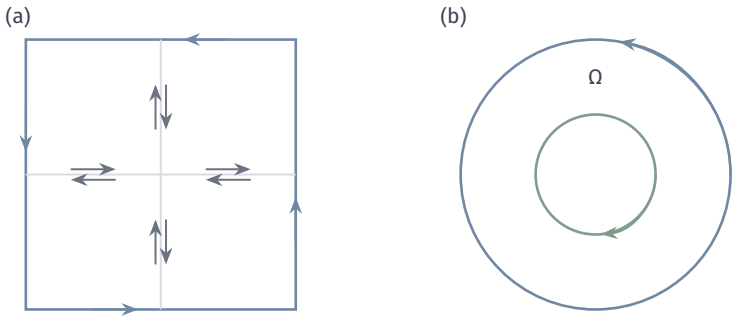


图 24.2 (a) 四个小正方形各取逆时针正向，共同边被沿相反方向走过；灰箭头略错开以便辨认，实际是同一条边。相加后只留下蓝色外边界。(b) 圆环的外边界逆时针、孔洞边界顺时针，沿任一边界前进时区域均在左侧。曲面拼片时也按公共边相反方向保证 Stokes 边界项相消。

24.2.1 Green 公式与平面边界

平面区域的边界是一维路径。对同一个二维向量场，可以沿边界累计切向分量，得到环流；也可以累计外法向分量，得到通量。两种边界积分分别对应区域内部的 Q_x-P_y 和散度 P_x+Q_y。

24.2.1.1 Green 公式的环流形式

旋度一节在小正方形上算出：逆时针环流约等于 Q_x-P_y 乘正方形面积。把区域 Ω 划分成许多小正方形（靠近弯曲边界处是不规则的小块），对每

块写出这一近似再相加。相邻两块的公共边在两块中方向相反，贡献抵消，剩下的只有沿 Ω 正向边界的环流；另一侧各块“$Q_x - P_y$ 乘面积”之和，则是区域积分的近似和。Green 公式说明，在适当条件下这一近似在加细后成为精确等式：区域内各处微小旋转的累计，等于沿边界走一圈的总环流。

定理 24.9　Green 公式　设 $\Omega \subseteq \mathbb{R}^2$ 为有界开区域，边界由有限条分段 C^1 简单闭曲线组成，且区域在每段光滑边界附近位于边界的一侧。边界取正向，即外边界逆时针、孔洞边界顺时针。若二维向量场 $\boldsymbol{F} = (P, Q)^{\top}$ 在 $\overline{\Omega}$ 的开邻域内连续可微，则Green 公式（Green's theorem）给出

$$\oint_{\partial\Omega} P\,\mathrm{d}x + Q\,\mathrm{d}y = \iint_{\Omega} \left(\frac{\partial Q}{\partial x} - \frac{\partial P}{\partial y} \right) \mathrm{d}x\,\mathrm{d}y. \tag{24.1}$$

左侧是向量场的切向路径积分，右侧是标量函数 $Q_x - P_y$ 的区域积分。在矩形上，这个等式可以直接由一元基本定理和累次积分公式推出。

矩形情形的证明　取 $\Omega = (a,b)\times(c,d)$，先写出左侧沿四条边的贡献。下边 (t,c)、$a \le t \le b$ 从左向右，$\mathrm{d}y = 0$，贡献 $\int_a^b P(x,c)\,\mathrm{d}x$；上边从 (b,d) 走到 (a,d)，贡献 $-\int_a^b P(x,d)\,\mathrm{d}x$；右边从下向上，贡献 $\int_c^d Q(b,y)\,\mathrm{d}y$；左边从上向下，贡献 $-\int_c^d Q(a,y)\,\mathrm{d}y$。水平边上 $\mathrm{d}y = 0$，竖直边上 $\mathrm{d}x = 0$，所以 Q 只在竖直边出现，P 只在水平边出现。

再看右侧。场在闭矩形附近连续可微，以下被积函数均可积。固定 x，对 y 用一元基本定理得 $\int_c^d \partial_y P(x,y)\,\mathrm{d}y = P(x,d) - P(x,c)$；再对 x 积分，并由连续函数的累次积分公式换成区域积分。对 Q 则先固定 y、对 x 积分。于是

$$-\iint_{\Omega} \partial_y P\,\mathrm{d}x\,\mathrm{d}y = \int_a^b [P(x,c) - P(x,d)]\,\mathrm{d}x,$$
$$\iint_{\Omega} \partial_x Q\,\mathrm{d}x\,\mathrm{d}y = \int_c^d [Q(b,y) - Q(a,y)]\,\mathrm{d}y.$$

第一行恰是下边与上边的两项，第二行恰是右边与左边的两项。四项合起来，正是沿下、右、上、左四条边逆时针行进得到的路径积分。 ∎

有限个矩形拼接时，公共边上的积分因方向相反而抵消。一般规则区域的证明还需处理区域分片及边界逼近误差，不能仅凭小矩形上的等式完成；这里引用一般形式，完整论证可参考向量微积分教材[3]。

先用旋转场在单位圆盘上核对公式两侧，并观察边界方向的作用。

[3] G. Strang, *Calculus: Chapter 15, Vector Calculus*, MIT OpenCourseWare, URL: https://ocw.mit.edu/courses/res-18-001-calculus-fall-2023/mitres_18_001_f17_ch15.pdf (visited on 10/19/2026)

示例 24.10　旋转场在单位圆盘上的 Green 公式　取 $\boldsymbol{F} = (P, Q)^{\top} = (-y, x)^{\top}$，$\Omega$ 为单位圆盘。$\boldsymbol{F}$ 在整个平面上连续可微，定理条件满足。右侧被积函数为 $Q_x - P_y = 1 - (-1) = 2$，区域积分为 $2 \cdot \pi = 2\pi$。左侧取逆时针边界 $\gamma(t) = (\cos t, \sin t)^{\top}$，$0 \le t \le 2\pi$，则 $\boldsymbol{F}(\gamma(t))^{\top}\gamma'(t) = \sin^2 t + \cos^2 t = 1$，积分同样为 2π。若把圆周改为顺时针，左侧变为 -2π，右侧仍为 2π，等式不再成立。

区域积分不含方向信息，边界积分却随方向反转而变号；Green 公式的符号由正向边界的约定决定。

Green 公式也可以反过来使用：选一个满足 $Q_x - P_y \equiv 1$ 的场，右侧就是区域的面积，于是面积可以由边界环流算出。

示例 24.11　用边界计算面积　设 Ω 满足定理 24.9的条件。取 $P = -y/2$、$Q = x/2$，则 $Q_x - P_y = 1$，Green 公式给出

$$\operatorname{area}(\Omega) = \frac{1}{2}\oint_{\partial\Omega} x\,\mathrm{d}y - y\,\mathrm{d}x.$$

对半轴为 $\alpha, \beta > 0$ 的椭圆区域，正向边界取 $\gamma(t) = (\alpha\cos t, \beta\sin t)^{\top}$、$0 \le t \le 2\pi$。这时 $\mathrm{d}x = -\alpha\sin t\,\mathrm{d}t$、$\mathrm{d}y = \beta\cos t\,\mathrm{d}t$，

$$x\,\mathrm{d}y - y\,\mathrm{d}x = (\alpha\beta\cos^2 t + \alpha\beta\sin^2 t)\,\mathrm{d}t = \alpha\beta\,\mathrm{d}t,$$

所以面积为 $\frac{1}{2}\cdot 2\pi\alpha\beta = \pi\alpha\beta$。

这个公式只需要沿边界走一圈、记录坐标与位移，就能得到所围面积；机械求积仪正是按这一原理工作的。

定理要求场在 $\overline{\Omega}$ 的开邻域内连续可微。区域包含场的奇点时，这一条件不再满足，下面的例子说明它不能省略。

示例 24.12　有孔区域上的涡旋场　第 22.4节的穿孔平面反例中，$\boldsymbol{F} = (-y, x)^{\top}/(x^2 + y^2)$ 在原点以外满足 $Q_x - P_y = 0$，但沿单位圆逆时针一周的环流为 2π。

取圆环 $\Omega = \{1 < x^2 + y^2 < 4\}$。它的闭包不含原点，$\boldsymbol{F}$ 在 $\overline{\Omega}$ 的一个开邻域内连续可微，Green 公式适用，右侧为 0。左侧由两圈组成。外圈 $r = 2$ 逆时针，参数化为 $(2\cos t, 2\sin t)^{\top}$，此时 $\boldsymbol{F} = (-\sin t, \cos t)^{\top}/2$，与速度 $(-2\sin t, 2\cos t)^{\top}$ 的内积为 1，环流为 2π；内圈 $r = 1$ 按正向取顺时针，环流为 -2π。两者相加为零，与右侧一致。

外圈逆时针为 2π、内圈顺时针为 -2π，也就是说，两条圆周按同一逆时针方向走时，环流都是 2π。环流来自原点处的奇点，而不是来自圆环内部。单位圆盘含有原点，$\boldsymbol{F}$ 在那里无定义，不满足 Green 公式的条件，所以不能由 $Q_x - P_y = 0$ 推出单位圆上的环流为零。

24.2.1.2　Green 公式的通量形式

现在把平面向量场想成薄层流体的速度场，考察单位时间有多少流体穿过区域边界流出。每个小正方形的净流出约等于散度乘面积。相邻两块的公共边上外法向相反，一块的流出就是另一块的流入，相加后抵消。因此可以预期，区域内部源强度的总和等于穿过边界的净流出。

计算通量需要把场投影到外法向上。正向边界的有向位移是 $\boldsymbol{\tau}\,\mathrm{d}s = (\mathrm{d}x, \mathrm{d}y)^{\mathsf{T}}$，而外法向由 $\boldsymbol{\tau}$ 顺时针转过直角得到，因此

$$\boldsymbol{n}\,\mathrm{d}s = (\mathrm{d}y, -\mathrm{d}x)^{\mathsf{T}}.$$

这一关系把法向通量写成切向路径积分，从而可以使用 Green 公式。

定理 24.13　平面区域的通量公式　在与 Green 公式相同的区域条件下，若 $\boldsymbol{F} = (F_1, F_2)^{\mathsf{T}}$ 在 $\overline{\Omega}$ 的开邻域内连续可微，$\boldsymbol{n}$ 是边界的外单位法向，则

$$\int_{\partial\Omega} \boldsymbol{F}^{\mathsf{T}}\boldsymbol{n}\,\mathrm{d}s = \iint_{\Omega} \operatorname{div}\boldsymbol{F}\,\mathrm{d}x\,\mathrm{d}y.$$

证明　利用外法向与正向边界的关系，$\boldsymbol{F}^{\mathsf{T}}\boldsymbol{n}\,\mathrm{d}s = F_1\,\mathrm{d}y - F_2\,\mathrm{d}x$，所以左侧等于 $\oint_{\partial\Omega}(-F_2)\,\mathrm{d}x + F_1\,\mathrm{d}y$。在 Green 公式中取 $(P, Q) = (-F_2, F_1)$，右侧被积函数为 $Q_x - P_y = \partial_x F_1 + \partial_y F_2 = \operatorname{div}\boldsymbol{F}$。 ■

这也是二维的散度公式。它与环流形式使用相同的区域条件，但累计的边界分量和内部导数不同。

下面在单位圆盘上比较两个场的通量：一个从各处均匀发散，一个只绕原点打转。

示例 24.14　单位圆盘上径向场与旋转场的通量　取 $\boldsymbol{F}(x, y) = (x, y)^{\mathsf{T}}$，$\Omega$ 为单位圆盘。散度为 $1 + 1 = 2$，区域积分为 2π。边界参数化为 $\gamma(t) = (\cos t, \sin t)^{\mathsf{T}}$，$0 \le t \le 2\pi$，外法向 $\boldsymbol{n} = \gamma(t)$，$\mathrm{d}s = \mathrm{d}t$，且 $\boldsymbol{F}^{\mathsf{T}}\boldsymbol{n} = \cos^2 t + \sin^2 t = 1$，所以边界通量也为 2π。若改取内法向，通量变为 -2π。

再取旋转场 $\boldsymbol{G} = (-y, x)^{\top}$。它的散度为 $0 + 0 = 0$；在单位圆上 $\boldsymbol{G}^{\top}\boldsymbol{n} = -y \cdot x + x \cdot y = 0$，通量为零，两侧一致。它的环流却是示例 24.10算出的 2π。

径向场好比流体在圆盘内各处均匀产生，产生的总量全部从圆周流出。旋转场则像杯中被搅动的水：水在杯中打转，却没有流出杯壁。通量与环流记录的是边界上两个不同的分量。

24.2.2 Gauss 公式与封闭曲面

将平面区域换成空间区域，边界就从曲线变成闭曲面。对应的关系仍是内部散度的积分等于边界的净通量。

24.2.2.1 Gauss 公式

仍把 $\boldsymbol{F}$ 看作流体的速度场。区域 Ω 内各处的散度给出单位体积的产生率，其体积积分是单位时间在 Ω 内产生的流体总量。流体总量守恒时，新产生的流体只能穿过边界离开，所以这个总量应等于穿过 $\partial\Omega$ 的外向净通量。

从计算上看，把 Ω 切成小立方体，每块的净流出约等于散度乘体积；相邻两块的公共面上外法向相反，流出与流入相消，只留下外边界上的通量。静电学中有同样的关系：电场穿过闭曲面的通量，由闭曲面内的总电荷决定[4]。Gauss 散度定理给出这一平衡精确成立的条件。

定理 24.15　Gauss 散度定理　设 $\Omega \subseteq \mathbb{R}^3$ 为有界开区域，其边界是由有限个正则 C^1 曲面片组成的闭曲面。各片内部互不相交，接缝为有限条分段 C^1 曲线及有限个点；在每个光滑边界点附近，区域位于边界的一侧。若向量场 $\boldsymbol{F}$ 在 $\overline{\Omega}$ 的一个开邻域内连续可微，则**散度定理**（divergence theorem）给出

$$\int_{\Omega} \nabla \cdot \boldsymbol{F}\, \mathrm{d}\boldsymbol{x} = \int_{\partial\Omega} \boldsymbol{F}^{\top}\boldsymbol{n}\, \mathrm{d}S, \tag{24.2}$$

其中 $\boldsymbol{n}$ 是光滑边界片上的外单位法向，$\mathrm{d}S$ 为面积元素。

光滑有界区域和通常的多面体满足这些条件。接缝的曲面面积为零，不影响通量积分；$\boldsymbol{F}$ 及其偏导数在紧集 $\overline{\Omega}$ 上连续因而有界，所以两侧积分都有限。左侧累计向量场的局部净流出率，右侧累计穿过整个外边界的净通量。

对长方体，这一等式不需要借助一般曲面逼近，可以逐坐标证明；证明正是把散度一节中小立方体上的近似计算改写成精确等式。

长方体情形的证明 取 $\Omega=(a,b)\times(c,d)\times(e,f)$。固定 (y,z)，对 x 用一元基本定理，再由连续函数的累次积分公式对 (y,z) 积分，得到

$$\int_\Omega \partial_x F_1 \,\mathrm{d}\boldsymbol{x} = \int_c^d \int_e^f [F_1(b,y,z)-F_1(a,y,z)]\,\mathrm{d}z\,\mathrm{d}y.$$

在 $x=b$ 面上外法向为 $(1,0,0)^{\mathsf T}$，$\boldsymbol{F}^{\mathsf T}\boldsymbol{n}=F_1$；在 $x=a$ 面上外法向为 $(-1,0,0)^{\mathsf T}$，$\boldsymbol{F}^{\mathsf T}\boldsymbol{n}=-F_1$。所以右侧正是这两张面的外向通量之和。同样，$\partial_y F_2$ 的体积积分等于 $y=d$ 与 $y=c$ 两面的通量之和，$\partial_z F_3$ 的体积积分等于 $z=f$ 与 $z=e$ 两面的通量之和。在其余各面上，相应分量与法向垂直，不贡献这一项。三式相加，左侧为散度的体积积分，右侧为六张面的全部外向通量。 ■

拼接长方体时，公共面上的外法向相反，内部通量恰好抵消。从长方体推广到定理中的一般规则区域，还需对边界分片和逼近作严格处理；一般形式在这里引用，证明可参考向量微积分教材[5]。无界区域、弱导数或更不规则的边界，需要另用相应版本，不能由长方体情形直接推出。

[5] G. Strang, *Calculus: Chapter 15, Vector Calculus*, MIT OpenCourseWare, URL: https://ocw.mit.edu/courses/res-18-001-calculus-fall-2023/mitres_18_001_f17_ch15.pdf (visited on 10/19/2026)

图 24.3显示体积小块相加时，共同面上的两份通量为什么消失。

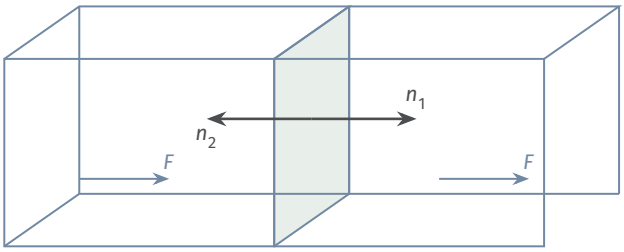


图 24.3 两个相邻单位立方体共用绿色面，图用斜投影表示三维几何。取常场 $F=(1,0,0)^{\mathsf T}$，共同面上两侧外法向为 $n_1=(1,0,0)^{\mathsf T}$ 与 $n_2=-n_1$，对应通量为 $1,-1$，相加抵消。整体外向净通量也为零，与散度为零一致；一般区域的散度定理仍需要前述条件与证明。

先用一个答案已知的计算核对散度定理。

示例 24.16 用散度定理核对球面面积 设 B_R 是以原点为中心、半径 $R>0$ 的球，边界球面取外法向。令 $\boldsymbol{F}(\boldsymbol{x})=\boldsymbol{x}/R$，它在整个 $\mathbb{R}^3$ 上

连续可微。球面上 $\boldsymbol{n} = \boldsymbol{x}/R = \boldsymbol{F}$，所以 $\boldsymbol{F}^{\top}\boldsymbol{n} = 1$，外向通量等于球面面积。另一方面，$\operatorname{div}\boldsymbol{F} = 3/R$，散度定理给出

$$\int_{\partial B_R} \boldsymbol{F}^{\top}\boldsymbol{n}\,\mathrm{d}S = \frac{3}{R}\operatorname{vol}(B_R) = \frac{3}{R}\cdot\frac{4\pi R^3}{3} = 4\pi R^2.$$

这里的球体积已在第 21.3节用球坐标算出；所得结果与第 23章直接参数化球面求得的面积一致。

定理要求 $\boldsymbol{F}$ 在 $\overline{\Omega}$ 的一个开邻域内连续可微。点源场在原点无定义，下面用它检查这一条件的作用。

示例 24.17　点源的通量　在 $\mathbb{R}^3 \setminus \{\mathbf{0}\}$ 上取 $\boldsymbol{F}(\boldsymbol{x}) = \boldsymbol{x}/\|\boldsymbol{x}\|_2^3$，记 $r = \|\boldsymbol{x}\|_2$。由 $\partial_j r = x_j/r$，

$$\partial_j\Big(\frac{x_j}{r^3}\Big) = \frac{1}{r^3} - \frac{3x_j^2}{r^5}$$

$$\operatorname{div}\boldsymbol{F} = \frac{3}{r^3} - \frac{3r^2}{r^5} = 0.$$

但在半径为 R 的球面上，外法向为 $\boldsymbol{x}/R$，$\boldsymbol{F}^{\top}\boldsymbol{n} = 1/R^2$，外向通量为 $4\pi R^2/R^2 = 4\pi$。这并不与散度定理矛盾：球体含有原点，而 $\boldsymbol{F}$ 在原点无定义，定理的条件不满足。

对不含原点的球壳 $R_1 < r < R_2$，定理适用，左侧为零。外球面的外向通量为 4π；内球面的外法向指向原点，通量为 -4π；两者相加确为零。

所以以原点为中心的球面上的通量都是 4π，与半径无关：场在原点以外处处无源，全部通量都来自原点处的点源。静电学中，位于原点的点电荷 q 产生的电场是 $\frac{q}{4\pi\varepsilon_0}\boldsymbol{F}$，其中 ε_0 为真空介电常数；它穿过以原点为中心的球面的通量为 q/ε_0，这就是 Gauss 定律在点电荷上的形式。

散度是通量密度　已证明的长方体情形，足以把散度一节的近似推导变成精确结论。设 $\boldsymbol{F}$ 在开集 U 上连续可微，$\boldsymbol{a} \in U$，Q_h 是以 $\boldsymbol{a}$ 为中心、边长为 h 的立方体；h 足够小时 $\overline{Q_h} \subseteq U$。由长方体上的 Gauss 公式，

$$\frac{1}{h^3}\int_{\partial Q_h} \boldsymbol{F}^{\top}\boldsymbol{n}\,\mathrm{d}S = \frac{1}{h^3}\int_{Q_h} \operatorname{div}\boldsymbol{F}\,\mathrm{d}\boldsymbol{x}.$$

右侧是散度在 Q_h 上的平均值，它与 $\operatorname{div}\boldsymbol{F}(\boldsymbol{a})$ 的差不超过 $\sup_{Q_h}|\operatorname{div}\boldsymbol{F} - \operatorname{div}\boldsymbol{F}(\boldsymbol{a})|$。散度连续，所以 $h \to 0$ 时这个上界趋于零，平均值趋于 $\operatorname{div}\boldsymbol{F}(\boldsymbol{a})$。

这说明散度确实是“单位体积的净流出”的极限。把立方体换成以 $\boldsymbol{a}$ 为中心的小球，用一般的 Gauss 公式可以得到同样的极限。小球的取法不依赖坐标轴，所以散度描述的是场本身的性质，不依赖坐标系的方向。

24.2.3 Stokes 公式与曲面的边界

Gauss 公式处理的是闭曲面围成的空间区域。另一类问题只给一张有边界的定向曲面，要比较曲面上的旋转累计与边界环流。这时使用旋度在曲面法向上的分量，不需要先把曲面补成闭曲面。

24.2.3.1 Stokes 公式

在 $z=0$ 平面上取向上法向时，旋度的法向分量 $(\nabla\times\boldsymbol{F})^{\top}\boldsymbol{e}_3$ 就是 Green 公式中的 Q_x-P_y。

对空间中的弯曲曲面，可以把它切成许多很小的曲面片，每片近似是一小块平面。在法向为 $\boldsymbol{n}$ 的小平面片上，边界环流约等于 $(\nabla\times\boldsymbol{F})^{\top}\boldsymbol{n}$ 乘面积。各片采用相容定向时，相邻两片的公共边被沿相反方向走过，环流相消，只剩整张曲面的边界。用桨轮的图像说：在曲面上各处放置转轴沿法向的小桨轮，它们感受到的旋转强度按面积累加，总和等于沿曲面边缘走一圈的环流。Stokes 公式把这一关系写成精确等式，同时要求法向与边界方向相容。

定理 24.18　Stokes 定理　设 $S\subseteq\mathbb{R}^3$ 为紧致、可定向的分片 C^2 曲面，边界由有限条分段 C^1 简单闭曲线组成。各光滑曲面片选取连续且片间定向相容的单位法向 $\boldsymbol{n}$，边界采用其诱导方向。若向量场 $\boldsymbol{F}$ 在 S 的开邻域内连续可微，则Stokes 公式（Stokes' theorem）给出

$$\oint_{\partial S}\boldsymbol{F}^{\top}\,\mathrm{d}\boldsymbol{r}=\int_{S}(\nabla\times\boldsymbol{F})^{\top}\boldsymbol{n}\,\mathrm{d}S. \tag{24.3}$$

这里的“可定向”要求各曲面片能相容地选择法向，使公共边上的诱导方向相反；有折角的接缝处不要求存在唯一法向。两侧都为标量：左侧是原向量场的边界环流，右侧是其旋度穿过曲面的通量。

在一张参数曲面片上，可以把公式归结为参数平面上的 Green 公式。设参数域 D 满足 Green 公式的区域条件，$\boldsymbol{r}(u,v)$ 在 D 的邻域内二阶连续可微、在内部正则且一一对应，并采用 $\boldsymbol{r}_u\times\boldsymbol{r}_v$ 确定的定向。还要求 ∂D 的正向经 $\boldsymbol{r}$ 对应曲面片边界的诱导方向，从而可以把边界路径积分放到 ∂D 上计算。这里的 u,v 是曲面的局部参数。记

$$A(u,v)=\boldsymbol{F}(\boldsymbol{r}(u,v))^{\top}\boldsymbol{r}_u(u,v),$$
$$B(u,v)=\boldsymbol{F}(\boldsymbol{r}(u,v))^{\top}\boldsymbol{r}_v(u,v).$$

先处理左侧。若 $(u(t),v(t))$ 沿 ∂D 行进，曲面边界上对应的点是 $\boldsymbol{r}(u(t),v(t))$，由链式法则，其速度为 $\boldsymbol{r}_u u'(t)+\boldsymbol{r}_v v'(t)$。与 $\boldsymbol{F}$ 取内积，得 $\boldsymbol{F}^{\top}\mathrm{d}\boldsymbol{r}=A\,\mathrm{d}u+B\,\mathrm{d}v$，所以左侧等于参数平面上的路径积分 $\oint_{\partial D} A\,\mathrm{d}u+B\,\mathrm{d}v$。

再计算参数平面上 Green 公式右侧的被积函数 $\partial_u B-\partial_v A$。记 $\boldsymbol{J}_{\boldsymbol{F}}$ 为 $\boldsymbol{F}$ 的 Jacobian 矩阵，其元素为 $(\boldsymbol{J}_{\boldsymbol{F}})_{i,j}=\partial_j F_i$。由链式法则和乘积法则，

$$\begin{aligned}\partial_u B&=(\boldsymbol{J}_{\boldsymbol{F}}\boldsymbol{r}_u)^{\top}\boldsymbol{r}_v+\boldsymbol{F}^{\top}\boldsymbol{r}_{vu},\\ \partial_v A&=(\boldsymbol{J}_{\boldsymbol{F}}\boldsymbol{r}_v)^{\top}\boldsymbol{r}_u+\boldsymbol{F}^{\top}\boldsymbol{r}_{uv},\end{aligned}$$

其中 $\boldsymbol{J}_{\boldsymbol{F}}$ 与 $\boldsymbol{F}$ 在 $\boldsymbol{r}(u,v)$ 处取值。$\boldsymbol{r}$ 二阶连续可微，混合偏导相等，$\boldsymbol{r}_{uv}=\boldsymbol{r}_{vu}$，所以两式相减时含二阶导数的项抵消。又 $(\boldsymbol{J}_{\boldsymbol{F}}\boldsymbol{r}_u)^{\top}\boldsymbol{r}_v=\boldsymbol{r}_v^{\top}\boldsymbol{J}_{\boldsymbol{F}}\boldsymbol{r}_u$、$(\boldsymbol{J}_{\boldsymbol{F}}\boldsymbol{r}_v)^{\top}\boldsymbol{r}_u=\boldsymbol{r}_v^{\top}\boldsymbol{J}_{\boldsymbol{F}}^{\top}\boldsymbol{r}_u$，于是

$$\partial_u B-\partial_v A=\boldsymbol{r}_v^{\top}(\boldsymbol{J}_{\boldsymbol{F}}-\boldsymbol{J}_{\boldsymbol{F}}^{\top})\boldsymbol{r}_u.$$

接下来把右端写成旋度。反对称矩阵 $\boldsymbol{W}=\boldsymbol{J}_{\boldsymbol{F}}-\boldsymbol{J}_{\boldsymbol{F}}^{\top}$ 的元素为 $\boldsymbol{W}_{i,j}=\partial_j F_i-\partial_i F_j$；逐个分量对照旋度的定义可以验证，对任意 $\boldsymbol{a}\in\mathbb{R}^3$ 都有 $\boldsymbol{W}\boldsymbol{a}=(\nabla\times\boldsymbol{F})\times\boldsymbol{a}$。再用混合积的轮换关系 $\boldsymbol{b}^{\top}(\boldsymbol{c}\times\boldsymbol{a})=\boldsymbol{c}^{\top}(\boldsymbol{a}\times\boldsymbol{b})$（两边都等于以 $\boldsymbol{a},\boldsymbol{b},\boldsymbol{c}$ 为列的行列式），取 $\boldsymbol{a}=\boldsymbol{r}_u$、$\boldsymbol{b}=\boldsymbol{r}_v$、$\boldsymbol{c}=\nabla\times\boldsymbol{F}$，得到

$$\partial_u B-\partial_v A=\big(\operatorname{curl}\boldsymbol{F}\big)(\boldsymbol{r}(u,v))^{\top}(\boldsymbol{r}_u\times\boldsymbol{r}_v).$$

右端乘 $\mathrm{d}u\,\mathrm{d}v$，正是曲面通量积分（式 (23.2)）中的被积项。

A,B 由连续可微的 $\boldsymbol{F}$ 与二阶连续可微的 $\boldsymbol{r}$ 及其一阶导数复合、相乘而成，在 D 的邻域内连续可微，所以参数平面上的 Green 公式适用；它给出该曲面片上的 Stokes 公式。对有限张相容定向的曲面片，公共边的路径积分相消，只剩整张曲面的边界。一般分片曲面的完整论证还需核对曲面覆盖及接缝条件；以上推导只说明参数片上的机制，一般定理可参考向量微积分教材[6]。

[6] G. Strang, *Calculus: Chapter 15, Vector Calculus*, MIT OpenCourseWare, URL: https://ocw.mit.edu/courses/res-18-001-calculus-fall-2023/mitres_18_001_f17_ch15.pdf (visited on 10/19/2026)

旋度分量是环流密度　Stokes 公式也给出旋度含义的精确形式。

设 $\boldsymbol{F}$ 在 $\boldsymbol{a}$ 附近连续可微，$\boldsymbol{n}$ 是单位向量，D_ρ 是以 $\boldsymbol{a}$ 为圆心、半径为 ρ、垂直于 $\boldsymbol{n}$ 并取法向 $\boldsymbol{n}$ 的平面圆盘。由 Stokes 公式，

$$\frac{1}{\pi\rho^2}\oint_{\partial D_\rho}\boldsymbol{F}^{\top}\mathrm{d}\boldsymbol{r}=\frac{1}{\pi\rho^2}\int_{D_\rho}(\nabla\times\boldsymbol{F})^{\top}\boldsymbol{n}\,\mathrm{d}S,$$

右侧是 $(\nabla\times\boldsymbol{F})^{\top}\boldsymbol{n}$ 在圆盘上的平均值。旋度连续，所以 $\rho\to 0$ 时它趋于 $(\nabla\times\boldsymbol{F})(\boldsymbol{a})^{\top}\boldsymbol{n}$。因此，旋度沿 $\boldsymbol{n}$ 的分量就是垂直于 $\boldsymbol{n}$ 的微小圆周上的环流除以所围面积的极限。这正是桨轮图像所描述的量；圆盘的取法不依赖坐标轴，所以这一含义也不依赖坐标轴的选取。

24.2.3.2 跨接曲面的选择

Stokes 公式的左侧只由有向边界和边界上的向量场决定。因此，若两张满足定理条件的定向曲面具有同一有向边界，且 $\boldsymbol{F}$ 在两张曲面附近都连续可微，则两张曲面上的旋度通量相等。计算时可以选较简单的跨接曲面，但必须核对向量场定义域，不能让替换曲面穿过场的奇点。

这一结论也可以从 Gauss 公式得到印证。若 $\boldsymbol{F}$ 二阶连续可微，前面已由混合偏导交换证明 $\operatorname{div}(\operatorname{curl}\boldsymbol{F}) = 0$。设两张跨接曲面恰好围成一个满足 Gauss 公式条件的区域，且 $\boldsymbol{F}$ 在该区域闭包的开邻域内二阶连续可微。区域的外法向在一张曲面上与所选法向相同，在另一张上相反；旋度场的散度为零，所以散度定理说明两张曲面上的旋度通量之差为零。

下面用同一个场在单位圆上比较两张跨接曲面。

示例 24.19　单位圆上的圆盘与半球面　取 $\boldsymbol{F} = (-y/2, x/2, 0)^{\top}$，它在整个 $\mathbb{R}^3$ 上连续可微，示例 24.4已算出 $\nabla \times \boldsymbol{F} = (0,0,1)^{\top}$。单位圆 $\{x^2 + y^2 = 1,\ z = 0\}$ 采用从上方看逆时针的方向。

先取向上单位圆盘 S_1。由示例 24.8，它的诱导方向正是这一方向；旋度的法向分量为 1，所以

$$\oint_{\partial S_1} \boldsymbol{F}^{\top}\,\mathrm{d}\boldsymbol{r} = \iint_{S_1} 1\,\mathrm{d}S = \pi.$$

直接计算左侧也得到同一结果：取 $\gamma(t) = (\cos t, \sin t, 0)^{\top}$，$0 \le t \le 2\pi$，则 $\boldsymbol{F}(\gamma(t))^{\top}\gamma'(t) = \tfrac{1}{2}(\sin^2 t + \cos^2 t) = \tfrac{1}{2}$，积分为 π。

再取外向上半单位球面 S_2，同一例子说明它的诱导方向与 S_1 相同。用第 23章的球面参数 (φ, θ)，$0 \le \varphi \le \pi/2$，外法向为 $\boldsymbol{n} = \boldsymbol{x}$，旋度的法向分量为 $z = \cos\varphi$，面积元为 $\sin\varphi\,\mathrm{d}\varphi\,\mathrm{d}\theta$，所以

$$\int_{S_2} (\nabla \times \boldsymbol{F})^{\top}\boldsymbol{n}\,\mathrm{d}S = \int_0^{2\pi}\int_0^{\pi/2} \cos\varphi \sin\varphi\,\mathrm{d}\varphi\,\mathrm{d}\theta = 2\pi \cdot \frac{1}{2} = \pi,$$

与圆盘上的结果相同。

若改用向下定向的圆盘，边界方向也必须反转，两个积分同时变号。

图 24.4比较同一有向圆周的两张跨接曲面。替换曲面时，边界方向与场的定义域都要同时保留。

24.2.4 分部积分与 Green 恒等式

分部积分把导数从一个因子转移到另一个因子，同时留下边界上的贡献。Gauss 公式给出它的多元形式。

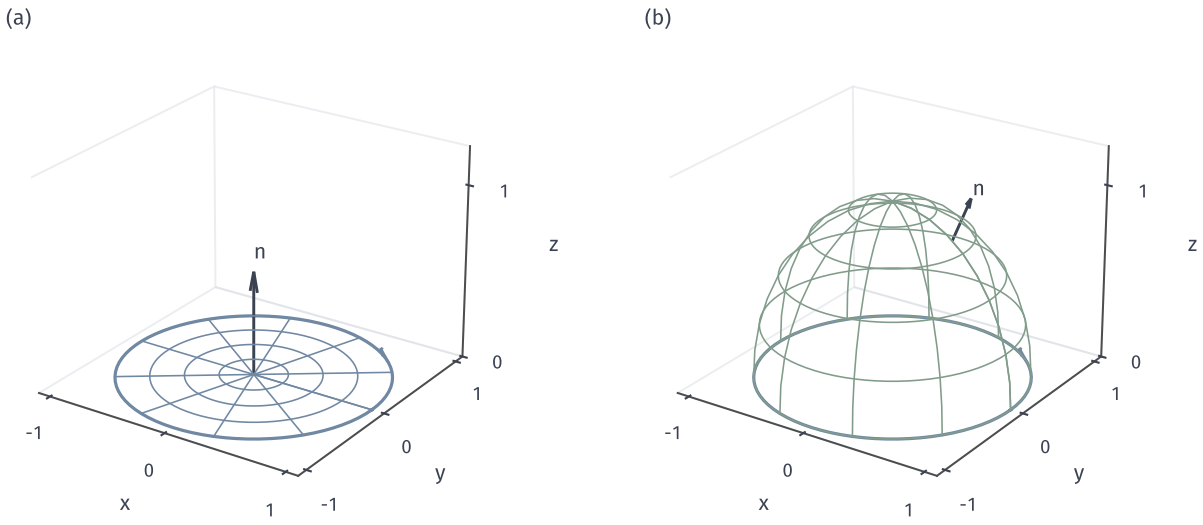


图 24.4 (a) 向上单位圆盘；(b) 外向上半单位球面。蓝色边界均从上方看逆时针，黑箭头标记各自法向。对 $F=(-y/2,x/2,0)^{\top}$，旋度恒为 $(0,0,1)^{\top}$，两面上的旋度通量都为 π。右面面积为 2π 而非 π；相等的是法向分量的累计，不能把通量当成面积。

设 Ω 满足 Gauss 公式的区域条件，标量函数 u 与向量场 $\boldsymbol{F}$ 在 $\overline{\Omega}$ 的开邻域内都是 C^1。逐坐标使用乘积法则，得到

$$\operatorname{div}(u\boldsymbol{F}) = \nabla u^{\top}\boldsymbol{F} + u\operatorname{div}\boldsymbol{F}.$$

对两边积分，左侧用 Gauss 公式化为边界通量，再移项，得到

$$\int_{\Omega} u\operatorname{div}\boldsymbol{F}\,\mathrm{d}V = \int_{\partial\Omega} u\boldsymbol{F}^{\top}\boldsymbol{n}\,\mathrm{d}S - \int_{\Omega}\nabla u^{\top}\boldsymbol{F}\,\mathrm{d}V.$$

若边界上 $u=0$，或 $\boldsymbol{F}$ 的法向分量为零，边界项消失；一般情况下必须保留它。

最常用的是 $\boldsymbol{F}=\nabla v$ 的情形，它对应一元分部积分。一元分部积分 $\int_a^b u\,w'\,\mathrm{d}x = [uw]_a^b - \int_a^b u'w\,\mathrm{d}x$（$u,w$ 在 $[a,b]$ 上连续可微）把一个因子的导数转给另一个因子，并留下端点项，可参考卷一第 7 章“一元函数的积分”。设 u 在 $[a,b]$ 上连续可微、v 二阶连续可微，取 $w=v'$，得到

$$\int_a^b u\,v''\,\mathrm{d}x = u(b)v'(b)\cdot(+1) + u(a)v'(a)\cdot(-1) - \int_a^b u'v'\,\mathrm{d}x.$$

这里把端点项 $[uv']_a^b$ 拆开写：区间在右端点的外法向是 $+1$，在左端点是 -1。

推广到多元情形时，各项依次对应：v'' 换成 Δv，$u'v'$ 换成梯度的内积 $\nabla u^{\top}\nabla v$，两个端点换成边界曲面，“v' 乘外法向 ±1”换成 v 沿外法向的方向导数 $\nabla v^{\top}\boldsymbol{n}$。

定理 24.20　多元分部积分　设 $\Omega \subseteq \mathbb{R}^3$ 满足上述 Gauss 公式的区域条件。若标量函数 u 在 $\overline{\Omega}$ 的开邻域内连续可微，v 在同一邻域内二阶连续可微，则

$$\int_\Omega u\Delta v \,\mathrm{d}\boldsymbol{x} = \int_{\partial\Omega} u\nabla v^{\mathsf{T}}\boldsymbol{n}\,\mathrm{d}S - \int_\Omega \nabla u^{\mathsf{T}}\nabla v \,\mathrm{d}\boldsymbol{x}.$$

证明　向量场 $\boldsymbol{F} = u\nabla v$ 的第 j 个分量是 $u\,\partial_j v$，它连续可微。由一元乘积法则，$\partial_j(u\,\partial_j v) = \partial_j u\,\partial_j v + u\,\partial_j^2 v$，对 j 求和得到

$$\operatorname{div}(u\nabla v) = \nabla u^{\mathsf{T}}\nabla v + u\Delta v.$$

将它代入 Gauss 公式，再把 $\nabla u^{\mathsf{T}}\nabla v$ 的区域积分移到等式另一侧，即得结论。 ■

对满足 Green 公式条件的平面区域，同样的证明改用平面通量公式（定理 24.13）即可，边界上的面积元相应换成弧长元。这一公式把 v 的二阶导数转为 u 与 v 的一阶导数，同时留下法向边界项；该项是否为零，要由具体的边界条件决定。

取 $u = 1$，公式化为 $\int_\Omega \Delta v\,\mathrm{d}\boldsymbol{x} = \int_{\partial\Omega} \nabla v^{\mathsf{T}}\boldsymbol{n}\,\mathrm{d}S$，也就是对梯度场 ∇v 使用散度定理。下面在球上核对这一特例。

示例 24.21　球上平方范数的 Laplace 积分　取以原点为中心、半径为 R 的球 B_R 和 $v(\boldsymbol{x}) = \|\boldsymbol{x}\|_2^2$。区域一侧，$\Delta v = 6$ 是常数，所以 $\int_{B_R}\Delta v\,\mathrm{d}\boldsymbol{x} = 6\,\mathrm{vol}(B_R) = 6\cdot\dfrac{4\pi R^3}{3} = 8\pi R^3$。边界一侧，球面上 $\nabla v = 2\boldsymbol{x}$，外法向为 $\boldsymbol{n} = \boldsymbol{x}/R$，法向导数 $\nabla v^{\mathsf{T}}\boldsymbol{n} = 2\|\boldsymbol{x}\|_2^2/R = 2R$ 同样是常数，乘以球面面积得 $2R\cdot 4\pi R^2 = 8\pi R^3$。两侧相等：$v$ 在球内各处的弯曲总量，等于它在球面上向外的增长率的累计。

边界项为零时，公式可以给出结构性的结论。下面用它说明 Laplace 方程的解由边界值唯一确定。

示例 24.22　Laplace 方程的解由边界值决定　设 Ω 满足 Gauss 公式的区域条件，w 在 $\overline{\Omega}$ 的开邻域内二阶连续可微，在 Ω 内 $\Delta w = 0$，在 $\partial\Omega$ 上 $w = 0$。在定理 24.20中取 $u = v = w$。左侧被积函数 $w\Delta w$ 为零；边界项的被积函数含因子 w，也为零。于是

$$\int_\Omega \|\nabla w\|_2^2\,\mathrm{d}\boldsymbol{x} = 0.$$

被积函数连续且非负；若它在某点为正，则在该点的一个邻域内为正，积分也为正。所以在开集 Ω 上 ∇w 恒为零。Ω 是连通的开区域，所以 w 在 Ω 上为常数；再由 w 在 $\overline{\Omega}$ 上连续且在边界上为零，得 $w \equiv 0$。

现在设 v_1, v_2 都在 $\overline{\Omega}$ 的开邻域内二阶连续可微，在 Ω 内满足 $\Delta v_1 = \Delta v_2 = 0$，在 $\partial\Omega$ 上取值相同。差 $w = v_1 - v_2$ 满足上面的全部条件，所以 $v_1 = v_2$。

按热传导的解释，稳定的温度分布由边界温度唯一决定。

若 u, v 都为 C^2 函数，交换分部积分公式中的 u, v，再将两式相减，梯度内积项抵消，得到 Green 第二恒等式：

$$\int_\Omega (u\Delta v - v\Delta u)\,\mathrm{d}\boldsymbol{x} = \int_{\partial\Omega} (u\nabla v - v\nabla u)^{\mathsf{T}}\boldsymbol{n}\,\mathrm{d}S.$$

前面的分部积分公式也称 Green 第一恒等式。两式要求同样的区域条件和边界定向。第二式说明，在积分中把 Δ 从 v 移到 u 上，差别只在边界项。

积分公式的比较 本节各公式回答的都是同一类问题：导数在内部的积分与边界积分之间的关系。推导方式也相同：在小块上建立局部关系，再利用相容方向让内部边界相消。它们的内部对象、边界对象和方向条件则各不相同。下表把一元基本定理与路径积分基本定理也列在一起，二者以区间或路径的两个端点为边界。

公式	内部积分	边界积分
一元基本定理	区间上的 f'	端点值之差 $f(b) - f(a)$
路径积分基本定理	路径上 $\nabla\phi$ 的切向积分	端点值之差
Green 环流形式	平面区域的 $Q_x - P_y$	正向路径的切向积分
Gauss	空间区域的散度	闭曲面的外向通量
Stokes	定向曲面的旋度通量	诱导方向的路径环流

对向上定向的平面曲面，Stokes 公式还原为 Green 公式的环流形式；Green 公式的通量形式则是二维的散度公式。普通标量函数的区域积分不自动具有边界表达：要使用这些公式，须先找到满足条件的向量场，使其散度或旋度的相应分量等于被积函数。示例 24.11的面积公式就是先选出满足 $Q_x - P_y \equiv 1$ 的场。

Stokes 公式还解释了第 22.4节中势函数的存在为何与定义域有关。设 $\boldsymbol{F}$ 在开集 $U \subseteq \mathbb{R}^3$ 上连续可微且 $\nabla \times \boldsymbol{F} = \boldsymbol{0}$。若一条闭路径是 U 内某张满足定理条件的定向曲面的有向边界，则该闭路径上的环流等于旋度的通量，也就是零。在星形域中，闭路径上各点与中心点之间的线段扫出一张锥面，它整个落在定义域内，不会碰到场的奇点；这与那里在星形域上构造势函

数的结论一致。穿孔平面上绕原点的单位圆则不同：在平面内，以它为边界的区域只能是单位圆盘，必然包含原点，而场在原点无定义；所以局部条件 $Q_x - P_y = 0$ 并不排除 2π 的环流（示例 24.12）。

使用这些公式时，要逐项核对连续可微性、分片规则的边界与定向。尤其要核对向量场是否在整个积分对象附近都有定义：穿孔平面上的涡旋场在原点无定义，不能把包含原点的圆盘直接代入 Green 公式；点源场也不能直接用于包含原点的球体（示例 24.17）。

区域积分中可以忽略的边界，在边界积分中正是累计的对象。所以必须知道场在边界上的实际取值，并检查它能否连续可微地延拓，不能只凭区域内部的积分值推断边界积分。若要降低导数或边界的规则性，还须另行建立弱导数、边界迹及相应的积分公式，不能沿用这里的公式而省去条件。

24.3 本章小结

散度与旋度是边界累计的局部密度。连续可微向量场的散度 $\sum_j \partial_j F_j$ 等于收缩立方体或小球上单位体积的外向净通量，也是 Jacobian 的迹；正值表示源，负值表示汇，散度为零只表示流入与流出平衡，不表示场为零。三维场的旋度沿单位向量 $\boldsymbol{n}$ 的分量，等于垂直于 $\boldsymbol{n}$ 的微小圆周上逆时针环流除以面积的极限；平面场对应的标量是 $Q_x - P_y$。

旋度与流线是否弯曲是两回事：剪切流的流线是直线而旋度不为零，涡旋场在原点以外流线弯曲而旋度为零。

Laplace 算子 $\Delta v = \operatorname{div} \nabla v$ 是 Hessian 的迹，度量一点的值与周围平均值之差；C^2 时 $\operatorname{curl} \nabla v = \mathbf{0}$ 与 $\operatorname{div} \operatorname{curl} \boldsymbol{F} = 0$ 来自混合偏导数的交换。

三个积分公式都由同一机制得到：在小块上建立局部关系，相容方向使内部公共边界的贡献相消。Green 公式把平面区域上 $Q_x - P_y$ 的积分化为正向边界上的环流，它的通量形式把散度的积分化为外向通量；正向边界要求区域总在行进方向的左侧，孔洞边界因而是顺时针。

Gauss 公式把空间区域上散度的积分化为闭曲面上的外向通量。Stokes 公式把定向曲面上旋度的通量化为诱导方向下的边界环流，平面情形还原为 Green 公式；具有同一有向边界的两张曲面给出相同的旋度通量，前提是场在两张曲面附近都连续可微。

区分闭曲面与有边界曲面：前者配外向通量和散度，后者配边界环流和旋度。由乘积法则与 Gauss 公式得到多元分部积分 $\int_\Omega u \Delta v = \int_{\partial\Omega} u \nabla v^{\top} \boldsymbol{n} - \int_\Omega \nabla u^{\top} \nabla v$，交换 u, v 相减得到 Green 第二恒等式。边界项是否消失取决于边界条件：边界值为零时它消失，并由此推出 Laplace 方程的解由边界值唯一确定。

使用这些公式时要逐项检查：场在整个积分对象的闭包附近连续可微，边界分片规则，法向与边界方向相容。穿孔平面上的涡旋场与原点处的点源场说明，局部的零旋度或零散度不能越过场的奇点推出零环流或零通量。放宽光滑性或边界规则性，需要另行建立弱导数与相应的积分公式。

参考文献

R. Barrett, M. Berry, T. F. Chan, J. Demmel, J. M. Donato, J. Dongarra, V. Eijkhout, R. Pozo, C. Romine, H. van der Vorst, *Templates for the Solution of Linear Systems: Building Blocks for Iterative Methods*, SIAM, 1994, 2nd ed.

C. Eckart, G. Young, *The Approximation of One Matrix by Another of Lower Rank* In Psychometrika, 1936, vol. 1, no. 3, pp. 211–218.

D. C.-L. Fong, M. Saunders, *LSMR: An Iterative Algorithm for Sparse Least-Squares Problems* In SIAM Journal on Scientific Computing, 2011, vol. 33, no. 5, pp. 2950–2971.

G. H. Golub, C. F. Van Loan, *Matrix Computations*, Johns Hopkins University Press, 2013, 4th ed.

P. C. Hansen, *Regularization Tools: A Matlab Package for Analysis and Solution of Discrete Ill-Posed Problems*, version 4.1, Technical University of Denmark, Mar. 2008.

J. Lebl, *Basic Analysis II: Introduction to Real Analysis*, version 6.3, May 15, 2026, URL: https://www.jirka.org/ra/ (visited on 10/19/2026).

C. C. Paige, M. A. Saunders, *LSQR: An Algorithm for Sparse Linear Equations and Sparse Least Squares* In ACM Transactions on Mathematical Software, 1982, vol. 8, no. 1, pp. 43–71.

G. Strang, *Calculus: Chapter 15, Vector Calculus*, MIT OpenCourseWare, URL: https://ocw.mit.edu/courses/res-18-001-calculus-fall-2023/mitres_18_001_f17_ch15.pdf (visited on 10/19/2026).

G. Strang, E. J. Herman, *Calculus Volume 3*, OpenStax, 2016.

T. Strohmer, R. Vershynin, *A Randomized Kaczmarz Algorithm with Exponential Convergence* In Journal of Fourier Analysis and Applications, 2009, vol. 15, no. 2, pp. 262–278.

A. Zouzias, N. M. Freris, *Randomized Extended Kaczmarz for Solving Least Squares* In SIAM Journal on Matrix Analysis and Applications, 2013, vol. 34, no. 2, pp. 773–793.

索引

一致连续，uniformly continuous，122
不变子空间，invariant subspace，178
不完全分解，incomplete factorization，397
严格行对角占优，strictly row diagonally dominant，347
主元，pivot，27
主夹角，principal angles，249
代数余子式，cofactor，39
代数重数，algebraic multiplicity，182
仿射映射，affine map，83
仿射空间，affine space，285
伴随，adjoint，168
修正 Gram–Schmidt，modified Gram–Schmidt，325
特征值，eigenvalue，176
特征向量，eigenvector，176
特征多项式，characteristic polynomial，179
特征方向，eigendirection，176
特征空间，eigenspace，178
环流，circulation，591
白化，whitening，293
直和，direct sum，64
相似，similar，95
相容，consistent，284
相对条件数，relative condition number，236
相对误差，relative error，235
相抵，equivalent matrices，92
矩阵函数，matrix function，228
矩阵分裂，matrix splitting，341
矩阵对数，matrix logarithm，231
矩阵平方根，matrix square root，220
矩阵方程，matrix equation，472
矩阵逼近，matrix approximation，438
秩，rank，87
稳定化双共轭梯度法，biconjugate gradient stabilized method，379
第一类曲面积分，scalar surface integral，610
第一类路径积分，scalar line integral，587
第二类曲面积分，flux integral，616
第二类路径积分，vector line integral，591
简单张量，simple tensor，49
算子范数，operator norm，130
线性子空间，linear subspace，61
线性无关，linearly independent，67
线性映射，linear map，79
线性泛函，linear functional，99
线性相关，linearly dependent，67
线性算子，linear operator，79
线性组合，linear combination，6
绝对条件数，absolute condition number，235
绝对误差，absolute error，234
维度重排，permutation of axes，45
维数，dimension，71
自伴，self-adjoint，170
自共轭矩阵，Hermitian matrix，151
范数，norm，106
薄奇异值分解，thin SVD，210
行列式，determinant，33
行最简形，reduced row echelon form，27
行空间，row space，84
行阶梯形，row echelon form，27
补空间，complement，64
诱导矩阵范数，induced matrix norm，129
谱，spectrum，200
谱半径，spectral radius，201
谱定理，spectral theorem，194
谱投影，spectral projection，198
谱范数，spectral norm，131
谱隙，spectral gap，251
赋范空间，normed space，106
路径，path，583
转置，transpose，4

轴，axis，45
近共线，nearly collinear，141
迭代矩阵，iteration matrix，343
迹，trace，41
逆矩阵，inverse matrix，28
逐元素乘积，Hadamard product，25
逐次超松弛迭代，successive over-relaxation，352
部分等距，partial isometry，226
部分选主元，partial pivoting，301
链式法则，chain rule，519
阶，order，45
隐函数，implicit function，545
零度，nullity，87
零空间，null space，84
鞍点，saddle point，533
预条件，preconditioning，396
预条件共轭梯度法，preconditioned conjugate gradient method，398
齐次最小二乘，homogeneous least squares，295

Arnoldi 正交化，Arnoldi process，365

Banach 空间，Banach space，126
Bartels–Stewart 算法，Bartels–Stewart algorithm，474

Cholesky 分解，Cholesky decomposition，305

Frobenius 内积，Frobenius inner product，43

Givens 旋转，Givens rotation，329
Golub–Kahan 双对角化，Golub–Kahan bidiagonalization，383
Gram–Schmidt 正交化，Gram–Schmidt orthogonalization，160
Gram 矩阵，Gram matrix，146
Green 公式，Green's theorem，632

Hessian 矩阵，Hessian matrix，526
Hilbert 空间，Hilbert space，143
Householder 反射，Householder reflection，326

Jacobian 矩阵，Jacobian matrix，516
Jordan 可测，Jordan measurable，571

Kaczmarz 算法，Kaczmarz method，404
Krylov 子空间，Krylov subspace，360

Lanczos 三项递推，Lanczos recurrence，372
Laplace 算子，Laplacian，627
Lipschitz 连续，Lipschitz continuous，122
LU 分解，LU decomposition，299
Lyapunov 方程，Lyapunov equation，481

Moore–Penrose 伪逆，Moore–Penrose pseudoinverse，290

QR 分解，QR factorization，162

Rayleigh 商，Rayleigh quotient，440

Schur 乘积，Schur product，149
Schur 补，Schur complement，313
Stokes 公式，Stokes' theorem，638
Sylvester 方程，Sylvester equation，472

Tikhonov 正则化，Tikhonov regularization，423

偏导数，partial derivative，498
像空间，image space，86
全微分，total differential，500
共轭梯度法，conjugate gradient method，361
内积，inner product，138
内积空间，inner-product space，138
几何重数，geometric multiplicity，182
分块 LDL 分解，block LDL factorization，309
列空间，column space，84
初等行变换，elementary row operation，27
前代，forward substitution，300
前向误差，forward error，418
加权低秩逼近，weighted low-rank approximation，459
加权最小二乘，weighted least squares，293
势函数，potential function，595
半正定，positive semidefinite，144
半范数，seminorm，109
双共轭梯度法，biconjugate gradient method，376
双正交，biorthogonality，376
反自伴，skew-adjoint，170
古典伴随，classical adjugate，40
可微，differentiable，500
后向稳定，backward stable，419
后向误差，backward error，418
向量化，vectorization，47
向量场，vector field，497
向量空间，vector space，60
商空间，quotient space，65

商范数，quotient norm，136
四个基本子空间，four fundamental subspaces，85
回代，back substitution，300
坐标，coordinates，73
基，basis，69
填充，fill-in，304
增广最小二乘，augmented least squares，423
增长因子，growth factor，304
奇异值，singular value，208
奇异值分解，singular value decomposition，208
奇异向量，singular vector，208
子空间最近点，nearest point in a subspace，286
完备，complete，126
定向，orientation，614
定常迭代，stationary iteration，341
实可对角化，real diagonalization，188
对偶基，dual basis，100
对偶映射，dual map，101
对偶空间，dual space，100
对偶范数，dual norm，134
对称逐次超松弛迭代，symmetric successive over-relaxation，354
局部条件数，local condition number，555
岭回归，ridge regression，422
左极分解，left polar decomposition，224
左零空间，left null space，85
幂等，idempotent，32
幂零，nilpotent，32
平行四边形恒等式，parallelogram identity，142
广义 Rayleigh 商，generalized Rayleigh quotient，454
广义最小残差法，generalized minimal residual method，368
广义特征问题，generalized eigenvalue problem，455
张成空间，span，66
张量，tensor，44
张量积，tensor product，48
归一化指数映射，softmax，518
形状重整，reshape，46

截断 SVD，truncated SVD，427，449
扩展 Kaczmarz 算法，extended Kaczmarz method，409
扰动，perturbation，233
散度，divergence，623
散度定理，divergence theorem，635
数值秩，numerical rank，422
斜投影，oblique projection，166
方向导数，directional derivative，499
旋度，curl，625
最佳正交逼近，best orthogonal approximation，463
最小二乘，least squares，286
最小最大原理，min-max principle，244
最小残差法，minimal residual method，373
最小范数解，minimum-norm solution，289
有向体积，oriented volume，36
有向面积，oriented area，35
条件数，condition number，238
松弛参数，relaxation parameter，352
极分解，polar decomposition，222
标准正交基，orthonormal basis，156
标量场，scalar field，496
梯度，gradient，510
正交，orthogonal，8
正交矩阵，orthogonal matrix，157
正交补，orthogonal complement，153
正定，positive definite，144
正规，normal，170
正规方程，normal equations，286
正规矩阵，normal matrix，202
满秩，full rank，87
滤波因子，filter factor，424
Woodbury 恒等式，Woodbury identity，318