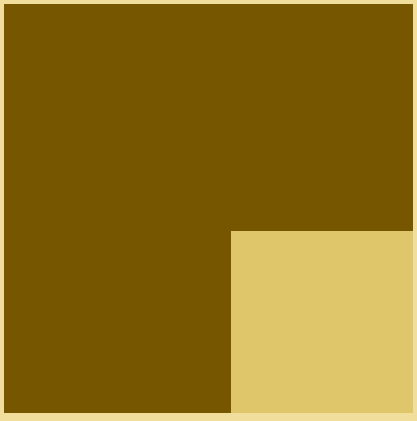
MATHEMATICS NOTES

数学笔记

卷五 · 优化



施晓罡

2026 年 · 第一版

MATHEMATICS NOTES

数学笔记

卷五 · 优化

施晓罡

2026 年 · 第一版

数学笔记

MATHEMATICS NOTES

作者：施晓罡

版本：第一版

年份：2026

Copyright © 2026 施晓罡

Licensed under the Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International License (the ”License”);

You may not use this file except in compliance with the License.

You may obtain a copy of the License at

https://creativecommons.org/licenses/by-nc-nd/4.0/

Unless required by applicable law or agreed to in writing, software distributed under the License is distributed on an ”AS IS” BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied. See the License for the specific language governing permissions and limitations under the License.

前言

本书目标

给定一个对象，我们怎样描述它的结构，判断它具有哪些性质，并据此进行计算？集合、函数、向量与图提供不同的描述方式；极限、测度与概率使这些描述能够处理逼近、连续变化与随机性；优化、微分方程和控制则进一步研究解怎样求得、状态怎样演化，以及行动怎样影响结果。本书围绕这些问题整理数学概念、推导与计算方法。

这份笔记供需要系统梳理相关数学工具的读者阅读。各章在具体对象和问题中引入定义，说明结论依赖的条件，并通过证明、算例和反例检查其适用范围。阅读时可以沿正文顺序建立基础，也可以从当前问题出发查阅相应章节，再补充所需的前置内容。

内容与阅读

全书按十卷组织。卷一《集合与一元微积分》建立集合、关系、映射与计数的语言，再研究实数上函数的极限、微分与积分；卷二《向量、矩阵与多元微积分》研究线性空间、谱分析、线性方程的求解与逼近，以及多元函数的微分与积分；卷三《图》研究图的结构与遍历、图上的组合优化、集合函数与子集选择，以及图上的动态规划；卷四《函数空间与流形》研究拓扑与度量、测度与积分、函数空间中的表示与逼近，以及流形上的几何与微积分。

此后各卷依次讨论优化，微分方程，概率，推断与因果识别，状态的演进与观测，以及决策、控制与博弈中的策略。目前已完成前五卷，其余各卷仍在整理；正文提到这些卷时，按全书计划的卷章位置给出可查阅之处。各卷独立构建，章节之间按需引用。

正文使用其他数学卷的结论时，会在当前问题中交代所需关系与条件，再给出可查阅的位置。

数学符号

下表汇总全书反复使用的记号。各章若赋予符号更具体的含义，会在首次使用时另行说明。

对象与线性代数

对象	常用记号	含义
数集	$\mathbb{N}$, $\mathbb{Z}$, $\mathbb{R}$, $\mathbb{R}_+$	自然数集、整数集、实数集和非负实数集
集合与关系	$x \in A$, $A \subseteq B$, $A \cup B$, $A \cap B$, $\lvert A \rvert$	元素属于集合、子集、并集、交集和有限集合的基数
标量	a, x, $\lambda \in \mathbb{R}$	单个数值；小写斜体字母通常表示标量
向量	$\boldsymbol{x}$, $\boldsymbol{w} \in \mathbb{R}^d$	d 维向量；加粗小写字母表示向量
矩阵	$\boldsymbol{A} \in \mathbb{R}^{m \times n}$, $\boldsymbol{A}_{i,j}$	m 行 n 列矩阵及其第 i 行、第 j 列元素
数据与样本	$\mathcal{D} = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^n$	含 n 个输入标签对的数据集；下标 i 表示样本索引
切片与迭代	$\boldsymbol{A}_{i,:}$, $\boldsymbol{A}_{:,j}$, $\boldsymbol{w}^{(t)}$	矩阵的第 i 行、第 j 列，以及第 t 次迭代的向量
Kronecker delta	$\delta_{i,j}$	当 $i = j$ 时取 1，否则取 0
矩阵变换	$\boldsymbol{A}^\top$, $\boldsymbol{A}^{-1}$, $\boldsymbol{A}^\dagger$, $\boldsymbol{I}_d$, $\operatorname{tr}(\boldsymbol{A})$	转置、逆、伪逆、d 阶单位矩阵和矩阵的迹
代数运算	$\langle \boldsymbol{x}, \boldsymbol{y} \rangle$, $\boldsymbol{x}^\top \boldsymbol{A} \boldsymbol{x}$, $\sum_i a_i$, $\prod_i a_i$	内积、二次型、求和与连乘
函数与模型	$f : \mathcal{X} \to \mathcal{Y}$, $h_{\boldsymbol{w}}(\boldsymbol{x})$	从输入空间到输出空间的函数，以及参数为 $\boldsymbol{w}$ 的模型
范数与距离	$\lVert \boldsymbol{x} \rVert_p$, $d(\boldsymbol{x}, \boldsymbol{y})$	p 范数与两对象之间的距离；具体定义由上下文给出

微积分与优化

对象	常用记号	含义
导数与梯度	$\dfrac{\mathrm{d}f}{\mathrm{d}x}$, $\nabla_{\boldsymbol{w}} L(\boldsymbol{w})$	一元导数，以及标量值函数对参数向量的梯度
Jacobian 与 Hessian	$\nabla_{\boldsymbol{x}} \boldsymbol{f}$, $\nabla_{\boldsymbol{x}}^2 f$	向量值函数的一阶偏导矩阵，以及标量值函数的二阶偏导矩阵
渐近阶	$f(n) = \mathcal{O}(g(n))$	函数增长率的渐近上界
最优化	$\min_{\boldsymbol{w}} L(\boldsymbol{w})$, $\boldsymbol{w}^* \in \arg\min_{\boldsymbol{w}} L(\boldsymbol{w})$	最小目标值与取得最小值的参数；最大化使用 max 和 arg max

概率与信息论

对象	常用记号	含义
随机变量与实现	$X,\ \boldsymbol{X},\ x,\ \boldsymbol{x},\ p_X(x)$	随机标量、随机向量及其实现值；p_X 表示概率质量或密度函数
联合与条件概率	$p(x,y),\ p(x \mid y)$	随机变量实现值的联合概率与条件概率
边缘概率	$p(x)=\sum_y p(x,y),\ p(x)=\int p(x,y)\,\mathrm{d}y$	分别对离散变量求和或对连续变量积分得到的边缘概率
独立性与抽样	$X \perp Y,\ X \perp Y \mid Z,\ X_i \overset{\text{i.i.d.}}{\sim} p$	独立、给定 Z 条件独立，以及独立同分布抽样
矩与相关性	$\mathbb{E}[X],\ \mathrm{Var}(X),\ \mathrm{Cov}(X,Y)$	期望、方差和协方差
常用分布	$\mathrm{Bernoulli}(p),\ \mathrm{Cat}(\boldsymbol{\pi}),\ \mathcal{N}(\boldsymbol{\mu},\boldsymbol{\Sigma})$	伯努利分布、类别分布和多元高斯分布
事件指示函数	$\mathbb{I}\{A\}$	事件 A 成立时取 1，否则取 0
信息量	$H(p),\ H(p,q),\ \mathrm{KL}(p\|\|q)$	熵、交叉熵和分布 p 相对于 q 的 KL 散度
概率正比关系	$p(\boldsymbol{x}) \propto q(\boldsymbol{x})$	忽略归一化常数时的概率正比关系

目录

第一部分	线性规划	1
第 1 章	优化问题与解	3
1.1	优化问题的表述	3
1.2	最优解的存在	10
1.3	解的性质	16
1.4	最优解的判别	23
1.5	近似解的评价	32
1.6	本章小结	40
第 2 章	线性规划	42
2.1	线性规划的表述	42
2.2	基本可行解	47
2.3	线性规划的对偶	59
2.4	线性松弛	69
2.5	本章小结	76
第 3 章	单纯形法	78
3.1	换基与最优性判别	78
3.2	初始可行基	89
3.3	退化的处理	97
3.4	修正单纯形法	102
3.5	对偶单纯形法	106
3.6	固定基的参数分析	112
3.7	最坏情形复杂度	115
3.8	本章小结	119

第 4 章 内点法 121
4.1 中心路径 121
4.2 原始—对偶路径跟踪 131
4.3 初始点 140
4.4 求解精度 145
4.5 多项式复杂度 149
4.6 单纯形法与内点法的比较 155
4.7 本章小结 158

第二部分 光滑优化 161

第 5 章 光滑优化基础 163
5.1 光滑性 163
5.2 步长的选择 173
5.3 求解误差与计算成本 190
5.4 本章小结 197

第 6 章 一阶方法 198
6.1 梯度下降 198
6.2 动量与加速 208
6.3 非线性共轭梯度法 224
6.4 收敛与计算成本 235
6.5 本章小结 238

第 7 章 二阶方法 239
7.1 Newton 法 239
7.2 阻尼 Newton 法 251
7.3 修正 Newton 法 259
7.4 非精确 Newton 法 268
7.5 收敛与计算成本 278
7.6 本章小结 281

第 8 章 拟牛顿法 283
8.1 割线条件 283
8.2 DFP 与 BFGS 289
8.3 SR1 298

8.4 L-BFGS 304
8.5 收敛与计算成本 310
8.6 本章小结 318

第 9 章 信赖域 320
9.1 信赖域模型 320
9.2 子问题的求解 329
9.3 步的接受与半径更新 340
9.4 收敛与计算成本 344
9.5 本章小结 351

第 10 章 鞍点的处理 353
10.1 驻点的类型 353
10.2 负曲率的检测 359
10.3 离开鞍点 367
10.4 停止条件与计算成本 383
10.5 本章小结 387

第三部分 非光滑优化 389

第 11 章 非光滑优化 391
11.1 次微分 392
11.2 次梯度方法 400
11.3 邻近方法 405
11.4 复合优化 413
11.5 光滑化 425
11.6 代理模型 438
11.7 本章小结 446

第四部分 分块优化 447

第 12 章 分块优化 449
12.1 分块问题 449
12.2 块坐标下降（BCD） 456
12.3 局部近似更新 465
12.4 交替极小化 475
12.5 块上界最小化（BSUM） 482

12.6 块邻近梯度（BPG） 486
12.7 实现与收敛 491
12.8 本章小结 500

第五部分 随机优化 503

第 13 章 随机梯度方法 505
13.1 随机目标与梯度估计 505
13.2 随机梯度方法 515
13.3 方差控制 532
13.4 随机动量方法 546
13.5 自适应更新 559
13.6 梯度的处理 571
13.7 误差与计算成本 578
13.8 本章小结 584

第 14 章 零阶随机优化 585
14.1 函数值反馈 585
14.2 有限差分 589
14.3 随机平滑与梯度估计 599
14.4 零阶随机梯度方法 610
14.5 误差与查询成本 621
14.6 本章小结 629

第 15 章 随机搜索 630
15.1 搜索问题 630
15.2 模拟退火 636
15.3 演化策略 646
15.4 遗传算法 659
15.5 粒子群 665
15.6 约束处理 671
15.7 含噪评价 674
15.8 结果评价 677
15.9 本章小结 680

第 16 章 贝叶斯优化 682
16.1 昂贵黑箱问题 682

16.2 概率代理 685
16.3 采集函数 693
16.4 顺序求解 700
16.5 含噪观测 707
16.6 约束下的选点 711
16.7 批量评价 714
16.8 预算与结果评价 717
16.9 本章小结 722

第六部分 约束优化 723

第 17 章 约束问题的最优性 725
17.1 约束问题 725
17.2 可行变化 729
17.3 约束资格 738
17.4 乘子条件 744
17.5 二阶条件 754
17.6 本章小结 762

第 18 章 对偶问题 765
18.1 下界的构造 765
18.2 弱对偶 772
18.3 凸共轭 777
18.4 强对偶 788
18.5 最优性证书 794
18.6 本章小结 800

第 19 章 参数敏感性 802
19.1 含参问题 802
19.2 最优值的变化 806
19.3 最优解的变化 820
19.4 分支变化 831
19.5 导数的计算与核验 837
19.6 本章小结 843

第 20 章 二次规划与锥规划 845
20.1 二次规划 845

20.2	锥规划	859
20.3	等价改写	874
20.4	半正定松弛	883
20.5	模型与求解方法	892
20.6	本章小结	894
第 21 章	**可行迭代**	**896**
21.1	可行集合上的更新	897
21.2	投影梯度法（PGD）	899
21.3	条件梯度法（Frank–Wolfe）	910
21.4	镜像下降	920
21.5	广义约化梯度法（GRG）	930
21.6	方法比较	939
21.7	本章小结	942
第 22 章	**惩罚与乘子方法**	**944**
22.1	二次惩罚法	945
22.2	精确惩罚法	955
22.3	对偶上升	964
22.4	增广 Lagrange 法（ALM）	973
22.5	交替方向乘子法（ADMM）	984
22.6	方法比较与计算成本	993
22.7	本章小结	995
第 23 章	**序列二次规划**	**997**
23.1	局部二次模型	997
23.2	等式 QP 的求解	1002
23.3	有效集法（Active-Set）	1008
23.4	曲率的处理	1018
23.5	更新的接受	1025
23.6	模型的修复	1031
23.7	收敛与计算成本	1036
23.8	本章小结	1040
第 24 章	**内点法**	**1042**
24.1	障碍问题	1042

24.2 原始—对偶内点法 1055
24.3 初始化与精度 1069
24.4 锥规划中的障碍 1076
24.5 保证与计算成本 1082
24.6 本章小结 1088

第 25 章 流形优化 1089
25.1 流形上的优化问题 1090
25.2 最优性与导数计算 1093
25.3 迭代的几何运算 1099
25.4 一阶方法 1109
25.5 二阶方法 1118
25.6 拟 Newton 法 1124
25.7 黎曼信赖域 1129
25.8 表示与计算成本 1135
25.9 本章小结 1139

第七部分 多目标与嵌套优化 1141

第 26 章 多目标优化 1143
26.1 多目标问题 1143
26.2 标量化 1152
26.3 最优解的判别 1164
26.4 多梯度下降 1172
26.5 前沿的计算 1180
26.6 前沿的评价 1186
26.7 本章小结 1192

第 27 章 极小极大优化 1194
27.1 极小极大问题 1194
27.2 最坏值函数 1197
27.3 鞍点 1203
27.4 内层响应法 1211
27.5 下降—上升方法 1219
27.6 校正方向 1225
27.7 结果评价 1235

27.8 本章小结 1240

第 28 章 双层优化 1242

28.1 双层问题 1242
28.2 内层解映射 1249
28.3 隐式微分 1254
28.4 迭代展开 1263
28.5 单层重述 1270
28.6 外层求解 1275
28.7 本章小结 1283

第八部分 泛函优化 1285

第 29 章 泛函优化 1287

29.1 泛函优化问题 1287
29.2 极小值的存在 1291
29.3 泛函的微分 1299
29.4 最优解的判别 1309
29.5 积分泛函 1316
29.6 有限维近似 1324
29.7 本章小结 1331

参考文献 1333

索引 1336

第一部分

线性规划

Linear Programming

阅读指引

买多少原料、开多少工时，才能在有限资源下获利最多？这类问题的目标和限制都是线性的，看上去朴素，却已经包含了优化的全部基本问题：什么叫解，解是否存在，算出来的结果怎样验证，又要花多少计算。本部分从这里开始建立全卷的语言。

第 1章是全卷的导论，把变量、目标和约束写成统一的形式，讨论最优解的存在、局部与全局的关系，以及算法给出的近似解该用什么标准评价。第 2章研究线性规划本身：可行域是多面体，最优解可以在顶点上取得，而约束的加权组合给出目标的下界，形成与原问题配对的对偶问题，两者的目标值相等时便构成最优性的证书。

后两章是求解线性规划的两条路线。第 3章的单纯形法沿着可行域的边从一个顶点走到相邻顶点；第 4章的内点法则从可行域内部穿过，沿一条光滑的路径逼近最优面。两者利用的结构不同，代价和返回的信息也不同，章末作了比较。

1.1 优化问题的表述
1.2 最优解的存在
1.3 解的性质
1.4 最优解的判别
1.5 近似解的评价
1.6 本章小结

第 1 章

优化问题与解

一个车间要安排两种产品的产量，工时和原料都有限，老板希望利润尽量高。一组观测要用几个系数拟合，我们希望拟合误差尽量小。两件事的内容毫不相干，问的却是同一句话：在允许的选择里，哪一个最好？

把这句话当真，马上会遇到一串问题。允许的选择可能一个也没有；选择可能越来越好，好到没有尽头；也可能越来越接近某个水平，却总差一点到不了。即使最好的选择存在，它也许不止一个。站在一个洼地的底部，四周都比脚下高，山那边却可能有更深的谷。最后，计算机交出来的只是一个“差不多”的点，我们还要说清它差多少。

可以把整章想成在地形图上找最低点：图上的位置是候选，地面高度是要比较的量，有些区域禁止进入。各节依次回答上面的问题。第 1.1节把任务写成数学对象，规定什么叫解，什么叫没有解。第 1.2节问解在什么条件下一定存在。第 1.3节比较两个候选之间的线段，回答洼地底部是不是最低处、最低点是不是只有一个。

前三节讨论的都是解本身。第 1.4节转到实际判断：手里有一个候选点，只看它附近的导数信息，能断定什么。第 1.5节处理算法真正交出的东西，比较衡量近似解的几种指标，并说明它们之间在什么条件下可以换算。这些语言和记号在全卷通用，后面每一章都在这个框架里提出自己的算法。

1.1 优化问题的表述

我们先要把“选最好的”这句话写到可以判断对错的程度。为此要说清在哪些候选里选、按什么标准比较，以及“选出来”究竟指什么。我们先看两个具体任务，再抽出共同的写法。

资源分配　一个车间生产两种产品，产量分别记为 x_1, x_2，单位是批。每批产品一的利润是 3，产品二的利润是 2。每批产品各用 1 个工时，每天共有 4 个工时；每批产品一用 2 份原料，产品二用 1 份，每天共有 6 份原料。产量不能为负。

车间能调整的只有 x_1, x_2 这两个数，把它们合成向量 $\boldsymbol{x} = (x_1, x_2)^\top \in \mathbb{R}^2$。要比较的是利润 $3x_1 + 2x_2$。允许的产量组合满足

$$x_1 + x_2 \le 4, \qquad 2x_1 + x_2 \le 6, \qquad x_1 \ge 0, \qquad x_2 \ge 0. \tag{1.1}$$

这里要的是利润最大，而全卷统一讨论最小化。两者只差一个符号：最大化 $3x_1 + 2x_2$ 与最小化 $-(3x_1 + 2x_2)$ 选出的产量相同，最大利润等于最小值的相反数。于是取

$$f(\boldsymbol{x}) = -(3x_1 + 2x_2). \tag{1.2}$$

把约束 (1.1)画在平面上，四条直线围出图 1.1中的浅蓝色四边形，产量只能在其中选。虚线是利润相等的产量组合，线旁的数字是利润值，线越往右上利润越高。利润为 10 的线恰好擦过四边形的一个角 $(2, 2)$，再往外推，线上就没有允许的点了。

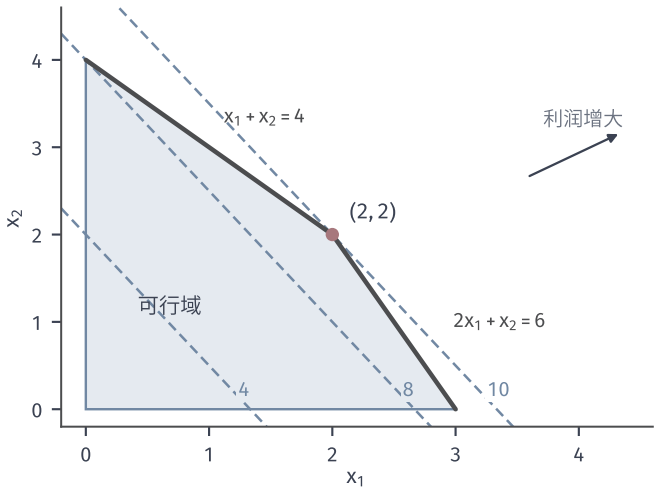


图 1.1 资源分配问题。浅蓝色四边形是全部允许的产量组合，顶点为 $(0,0), (3,0), (2,2), (0,4)$；深灰粗线是工时约束与原料约束的边界。蓝色虚线是利润等于 $4, 8, 10$ 的直线，红点 $(2,2)$ 是利润为 10 的线与四边形唯一的公共点。

二次拟合 第二个任务来自数据。设有 N 个观测和 n 个待定系数，矩阵 $\boldsymbol{A} \in \mathbb{R}^{N\times n}$ 的第 i 行记录第 i 个观测的输入，向量 $\boldsymbol{b} \in \mathbb{R}^N$ 记录观测值。系数 $\boldsymbol{x} \in \mathbb{R}^n$ 给出的预测是 $\boldsymbol{A}\boldsymbol{x}$，我们用平方误差比较不同的系数：

$$f(\boldsymbol{x}) = \frac{1}{2}\|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|_2^2 + \frac{\gamma}{2}\|\boldsymbol{x}\|_2^2, \qquad \gamma \ge 0. \tag{1.3}$$

第一项衡量预测与观测的差距，第二项称为正则项，系数 γ 决定对大系数收多少“费”。这个目标是 $\boldsymbol{x}$ 的二次函数，所以称为二次拟合。

全章反复使用一个最小的实例：只有一个观测，$N=1$；两个系数，$n=2$；$\boldsymbol{A}=(1\ \ 1)$，$\boldsymbol{b}=2$。它的含义是“只测到两个量的和约等于 2”。此时

$$f(\boldsymbol{x})=\frac{1}{2}(x_1+x_2-2)^2+\frac{\gamma}{2}(x_1^2+x_2^2). \tag{1.4}$$

这个例子小到可以手算，却已经包含解不唯一、平坦方向和误差指标互相矛盾这些现象。

统一的写法 两个任务都是在一个集合里选 $\boldsymbol{x}$，使一个数尽量小。我们把这个结构固定下来，并同时规定全卷的记号。

定义 1.1 优化问题 给定集合 $\boldsymbol{C}\subseteq\mathbb{R}^n$ 与函数 $f:\boldsymbol{C}\to\mathbb{R}$，寻找使 f 尽量小的 $\boldsymbol{x}\in\boldsymbol{C}$ 的任务称为**优化问题**（optimization problem），写作

$$\min_{\boldsymbol{x}\in\boldsymbol{C}} f(\boldsymbol{x}). \tag{1.5}$$

$\boldsymbol{x}$ 称为**决策变量**（decision variable），f 称为**目标函数**（objective function），$\boldsymbol{C}$ 称为**可行集**（feasible set），$\boldsymbol{C}$ 中的点称为**可行点**（feasible point）。

可行集常常由一组条件给出。全卷把不等式都整理成“≤ 0”的形式，写作

$$\boldsymbol{C}=\bigl\{\boldsymbol{x}\in\mathbb{R}^n:\ g_i(\boldsymbol{x})\le 0,\ i=1,\dots,m;\ h_j(\boldsymbol{x})=0,\ j=1,\dots,p\bigr\}. \tag{1.6}$$

其中 g_i 是不等式约束，共 m 个；h_j 是等式约束，共 p 个。资源分配里没有等式约束，四个不等式约束是

$$g_1(\boldsymbol{x})=x_1+x_2-4,\quad g_2(\boldsymbol{x})=2x_1+x_2-6,\quad g_3(\boldsymbol{x})=-x_1,\quad g_4(\boldsymbol{x})=-x_2.$$

二次拟合里没有约束，$\boldsymbol{C}=\mathbb{R}^n$。

$\boldsymbol{C}$ 与 f 必须一起给定，问题才算确定。对二次拟合而言，改变 γ 是在改变候选之间的比较标准，全部候选都还在；加上硬性要求 $x_1\ge 1.2$ 则是把一部分候选直接淘汰。前者像调整评分表，后者像修改参赛资格。两种改动都可能让答案变化，但机制不同，这一区别到本节末尾还会出现。

最优值与最优解 “最低点”其实包含两个问题：最低的高度是多少，这个高度在哪里取得。前者是一个数，后者是一个位置。两者要分开定义，因为第一个问题有答案时，第二个问题可能没有。

定义 1.2　最优值与最优解　问题 (1.5)的最优值（optimal value）是

$$f^\star = \inf_{\boldsymbol{x}\in\boldsymbol{C}} f(\boldsymbol{x}) \in [-\infty, +\infty], \tag{1.7}$$

并约定空集上的下确界为 $+\infty$。若可行点 $\boldsymbol{x}^\star$ 满足 $f(\boldsymbol{x}^\star) = f^\star$，就称它为最优解（optimal solution）。全体最优解组成的集合记为 $\arg\min_{\boldsymbol{x}\in\boldsymbol{C}} f(\boldsymbol{x})$。这个集合非空时，称最优值被达到。

符号 min 在式 (1.5)中只表示提出任务。若有人写“最小值等于某个数”，他同时断言了这个数被某个可行点取得；若只知道下确界，应当写 inf。

现在解资源分配问题。要证明 $(2,2)$ 最好，需要两件事：所有可行点的利润都不超过某个数，并且 $(2,2)$ 达到了这个数。第一件事可以这样做：利润系数 $(3,2)$ 恰好是两条资源约束系数 $(1,1)$ 与 $(2,1)$ 之和，所以对任意可行点，把两条约束相加，得到

$$3x_1 + 2x_2 = (x_1 + x_2) + (2x_1 + x_2) \le 4 + 6 = 10.$$

这说明 $f(\boldsymbol{x}) \ge -10$ 对所有可行点成立。等号成立当且仅当两条资源约束同时取等号，也就是

$$x_1 + x_2 = 4, \qquad 2x_1 + x_2 = 6.$$

解得 $\boldsymbol{x} = (2,2)$，它满足非负约束，因而可行。于是

$$f^\star = -10, \qquad \arg\min_{\boldsymbol{x}\in\boldsymbol{C}} f(\boldsymbol{x}) = \{(2,2)\}.$$

这个论证的结构值得记住：一个对所有可行点成立的下界，加上一个达到该下界的可行点，从两侧把最优值夹住，两者缺一不可。只有下界，不知道它是否够紧；只有候选点，不知道还有没有更好的。第 2章会说明，“给约束配权重再相加”可以系统地做。

二次拟合实例 (1.4)取 $\gamma = 0$ 时，$f(\boldsymbol{x}) = \frac{1}{2}(x_1 + x_2 - 2)^2 \ge 0$。凡满足 $x_1 + x_2 = 2$ 的点都使 $f = 0$，所以 $f^\star = 0$，最优解是一整条直线。比如 $(1,1)$ 和 $(3,-1)$ 都最优。数据只约束了两个量的和，没有约束它们的差，参数不唯一并不是计算失败，而是问题本身没有提供区分它们的信息。

三种没有最优解的情形　并不是每个问题都有解，失败有三种不同的方式，分别出在不同的环节。

- 不可行（infeasible）：$\boldsymbol{C} = \varnothing$，此时 $f^\star = +\infty$。例如同时要求 $x \le 0$ 与 $x \ge 1$。

- **无下界**（unbounded below）：$\boldsymbol{C} \neq \varnothing$ 且 $f^\star = -\infty$。例如在 $\mathbb{R}$ 上最小化 $f(x) = x$，取 $x = -k$ 可得 $f = -k \to -\infty$。
- **下确界未达到**：$f^\star$ 是有限实数，但 $\arg\min$ 为空。例如在 $\mathbb{R}$ 上最小化 $f(x) = e^x$。

第三种最容易被忽略。对 e^x, 处处有 $e^x > 0$, 又有 $e^{-k} \to 0$, 所以 $f^\star = 0$; 但没有 x 使 $e^x = 0$。只报告“最优值是 0”而不说明它未被达到，读者会以为存在一个最优的 x。图 1.2把三种情形放在一起。

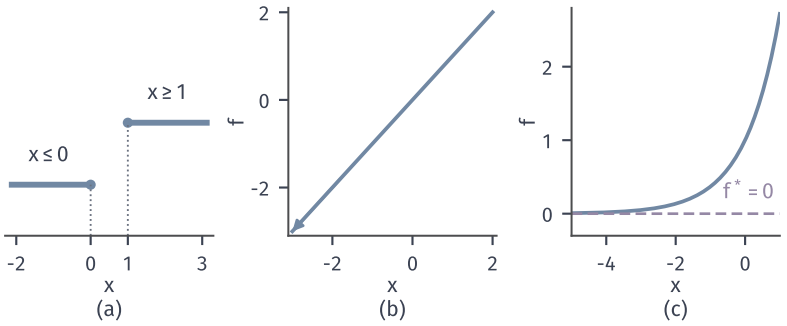


图 1.2　优化问题没有最优解的三种方式。(a) 约束 $x \le 0$ 与 $x \ge 1$ 对应的两段蓝色射线没有公共点，可行集为空。(b)$f(x) = x$ 沿箭头方向无限下降，最优值为 $-\infty$。(c)$f(x) = e^x$ 趋于紫色虚线 $f^\star = 0$ 却永远碰不到：最优值有限，但没有点取得它。

局部最优与全局最优　前面的最优解要和所有可行点比。实际计算时，我们往往只看得见当前点附近的情况，所以还需要一个只和附近比较的概念。“附近”用开球表示：

$$\boldsymbol{B}(\boldsymbol{x}, r) = \{\boldsymbol{y} : \|\boldsymbol{y} - \boldsymbol{x}\|_2 < r\}.$$

定义 1.3　局部最优解　设 $\boldsymbol{x}^\star \in \boldsymbol{C}$。若存在 $r > 0$，使

$$f(\boldsymbol{x}^\star) \le f(\boldsymbol{x}) \qquad \text{对所有 } \boldsymbol{x} \in \boldsymbol{C} \cap \boldsymbol{B}(\boldsymbol{x}^\star, r) \text{ 成立，} \tag{1.8}$$

就称 $\boldsymbol{x}^\star$ 为**局部最优解**（local minimizer）。若对其中所有 $\boldsymbol{x} \neq \boldsymbol{x}^\star$ 都有严格不等式，就称它为**严格局部最优解**（strict local minimizer）。定义 1.2中的最优解也称**全局最优解**（global minimizer）。

比较的范围是 $\boldsymbol{C} \cap \boldsymbol{B}(\boldsymbol{x}^\star, r)$，不是整个球。可行集边界上的点只需要和球内的可行点比较，球里伸出可行集的部分不参加比较。下面的例子同时展示洼地与边界。

示例 1.4　两个洼地与一个边界　在可行集 $\boldsymbol{C} = [-1.5, 1.5]$ 上最小化

$$f(x) = \frac{x^4}{4} - \frac{x^3}{3} - x^2.$$

先求导并分解因式：

$$f'(x) = x^3 - x^2 - 2x = x(x-2)(x+1).$$

所以 f' 在 $x = -1, 0, 2$ 处为零。其中 $x = 2$ 在可行集之外。由 f' 的符号，f 在 $[-1.5, -1]$ 上递减，在 $[-1, 0]$ 上递增，在 $[0, 1.5]$ 上递减。

因此 $x = -1$ 附近的可行点函数值都不低于 $f(-1)$，它是局部最优解。$\boldsymbol{C}$ 上的最小值只可能出现在 $x = -1$ 或右端点 $x = 1.5$，两处的函数值是

$$f(-1) = -\frac{5}{12} \approx -0.417, \qquad f(1.5) \approx -2.109.$$

所以全局最优解是 $x = 1.5$。这一点在边界上，那里 $f'(1.5) = -1.875 \neq 0$：函数还在向右下降，只是可行集不允许再往右走。

图 1.3画出这个例子，地形的比喻在这里很贴切。黄点是一个洼地的底部，站在那里四周都更高，它却不是最低处。红点是真正的最低处，脚下的地面还是斜的，挡住我们的是边界，不是地形。可行集右侧还有更低的点 $x = 2$，但它不是候选，与问题无关。

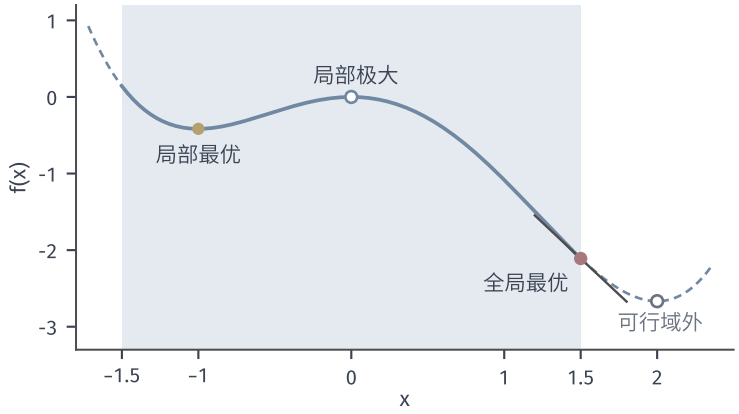


图 1.3　$f(x) = x^4/4 - x^3/3 - x^2$ 在 $\boldsymbol{C} = [-1.5, 1.5]$（浅蓝色带）上的局部与全局最优。蓝色实线是 $\boldsymbol{C}$ 上的图像，虚线是 $\boldsymbol{C}$ 外的部分。黄点 $x = -1$ 是局部最优解，红点 $x = 1.5$ 是全局最优解，该处的短切线不水平，斜率为 -1.875。空心点分别是局部极大点 $x = 0$ 和可行集外的 $x = 2$。

严格局部最优只说明一个小邻域内没有并列者，并不排除远处有同样低的点。函数 $(x^2 - 1)^2$ 在 $x = \pm 1$ 处都取到全局最小值 0，两点各自是严格局部最优解，全局最优解却有两个。

把约束并入目标 到目前为止，可行集和目标是两个分开的对象。后面常要把几种代价相加，或者用同一个工具处理各种约束，分开写很不方便。一个自然的想法是：给不可行的点一个大到不可能被选中的值。任何有限的数都不够保险，所以我们允许函数取 $+\infty$。

定义 1.5 扩展实值函数与约束指标函数 取值于 $\mathbb{R}\cup\{+\infty\}$ 的函数称为**扩展实值函数**（extended real-valued function）。它的**有效定义域**（effective domain）是 $\operatorname{dom} F=\{\boldsymbol{x}:F(\boldsymbol{x})<+\infty\}$；有效定义域非空时，称 F 为**适当函数**（proper function）。集合 $\boldsymbol{C}\subseteq\mathbb{R}^n$ 的**约束指标函数**（constraint indicator function）是

$$\iota_{\boldsymbol{C}}(\boldsymbol{x})=\begin{cases}0, & \boldsymbol{x}\in\boldsymbol{C},\\ +\infty, & \boldsymbol{x}\notin\boldsymbol{C}.\end{cases}\tag{1.9}$$

扩展实值目标 F 的最优解集合规定为

$$\arg\min F=\{\boldsymbol{x}\in\operatorname{dom}F:F(\boldsymbol{x})=\inf F\}.\tag{1.10}$$

对可行集 $\boldsymbol{C}$ 非空的问题，令 $F=f+\iota_{\boldsymbol{C}}$，也就是在 $\boldsymbol{C}$ 上 $F=f$，在 $\boldsymbol{C}$ 外 $F=+\infty$。这里 $f+\iota_{\boldsymbol{C}}$ 在 $\boldsymbol{C}$ 外按 $+\infty$ 理解，不要求 f 在那里有定义。逐项核对这种写法保留了什么。

首先，$\operatorname{dom}F=\boldsymbol{C}$，所以取有限值的候选恰好是可行点。其次，$F$ 与 f 在可行点上取值相同，其余点取 $+\infty$，不影响下确界，于是

$$\inf_{\mathbb{R}^n}F=\inf_{\boldsymbol{x}\in\boldsymbol{C}}f(\boldsymbol{x}).$$

最后，最优解只在 $\operatorname{dom}F=\boldsymbol{C}$ 中找，所以 $\arg\min F$ 与原问题的最优解集合相同。若 $\boldsymbol{C}=\varnothing$，则 $F\equiv+\infty$ 不是适当函数，应报告不可行；定义中限定在 $\operatorname{dom}F$ 内找解，正是为了避免说成“每一点都最优”。

约束指标函数不是普通指示函数 名称相近的**普通指示函数**（indicator function）$\mathbb{1}_{\boldsymbol{C}}$ 在 $\boldsymbol{C}$ 上取 1，在 $\boldsymbol{C}$ 外取 0。两者的取值表放在一起，就能看出差别。

	$\boldsymbol{x}\in\boldsymbol{C}$	$\boldsymbol{x}\notin\boldsymbol{C}$
约束指标函数 $\iota_{\boldsymbol{C}}$	0	$+\infty$
普通指示函数 $\mathbb{1}_{\boldsymbol{C}}$	1	0

表 1.1 约束指标函数与普通指示函数的取值。前者用于把违规点排除，后者只是记录一个点是否属于集合。

1.1 优化问题的表述
1.2 最优解的存在
1.3 解的性质
1.4 最优解的判别
1.5 近似解的评价
1.6 本章小结

两者的方向也相反：ι_C 在集合内为小值，$\mathbb{1}_C$ 在集合内为大值。用一个例子看把它们加到目标上的后果。在约束 $x \le 1$ 下最小化 $(x-2)^2$，可行集记为 $C = (-\infty, 1]$。这个问题的最优解是 $x = 1$，最优值为 1。

图 1.4比较三种加法。加 ι_C 得到的问题就是原问题。加 $\mathbb{1}_C$ 则让可行点反而贵了 1，最小点跑到 $x = 2$，违反约束。

第三种是有限惩罚，它按违规程度收费。改为最小化 $(x-2)^2 + \max\{0, x-1\}$，在 $x > 1$ 的范围内令导数为零：

$$2(x-2) + 1 = 0, \qquad x = 1.5.$$

此处函数值是 $0.25 + 0.5 = 0.75$，低于约束问题的最优值 1，所以惩罚问题的最小点违反了约束。

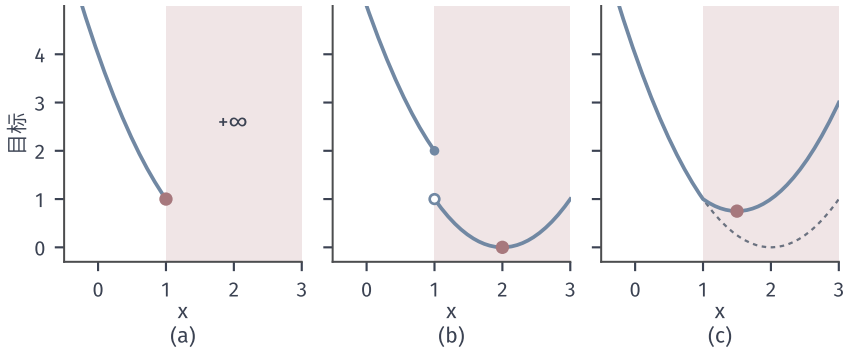


图 1.4 把约束 $x \le 1$ 并入目标 $(x-2)^2$ 的三种做法，浅红区域是不可行的点，红点是所得问题的最小点。(a) 加约束指标函数，浅红区域取 $+\infty$，最小点 $x = 1$ 与原问题相同。(b) 加普通指示函数，可行点上升 1，最小点变成不可行的 $x = 2$。(c) 加有限惩罚 $\max\{0, x-1\}$（灰色点线是原目标），最小点 $x = 1.5$ 仍不可行。

约束指标函数只是把同一个问题换了写法；有限惩罚改变了问题，只是不喜欢违规，并不禁止违规。惩罚要多大才能恢复约束，是第 22章的话题。今后需要时，我们把约束问题 (1.5)直接写成扩展实值目标的最小化，两种写法描述同一个问题。

1.2 最优解的存在

e^x 的例子说明，最优值有限并不保证有点取得它。于是要问：在什么条件下，可以不解问题就断定最优解存在？这个问题值得先回答。若解根本不存在，算法再怎么迭代也找不到它，“收敛”二字也就无从谈起。

从越来越好的候选出发 设 C 非空。按下确界的定义，总能取到一列可行点，使目标值趋于 $f^\star$。若 $f^\star$ 有限，就对每个 k 取可行点 $\boldsymbol{x}^{(k)}$，使

$f(\boldsymbol{x}^{(k)}) \le f^\star + 1/k$；若 $f^\star = -\infty$，就取 $f(\boldsymbol{x}^{(k)}) \le -k$。这样的序列称为**最小化序列**（minimizing sequence）。上标 (k) 只是序列编号，这里还没有任何算法。

最小化序列的目标值越来越接近最优值，但序列本身可能乱跑。要从它得到一个最优解，需要依次通过三关：

1. 序列留得住：存在收敛的子列，候选不会四散或逃向无穷远；
2. 极限合法：子列的极限仍然是可行点；
3. 比较能传到极限：极限处的目标值不高于序列目标值的极限。

前两关由可行集负责，第三关由目标函数负责。图 1.5中的三个例子各拆掉一关，绿点是最小化序列。

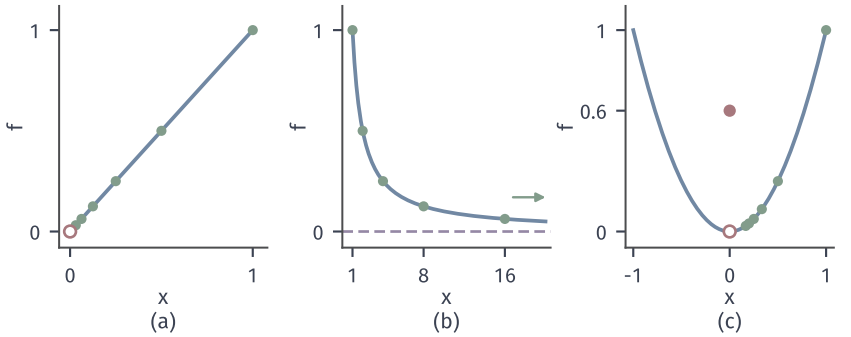


图 1.5　存在性论证的三关分别失败。绿点是最小化序列。(a)$f(x) = x$，$C = (0, 1]$：序列 2^{-k} 趋于不可行的端点 0（红色空心点）。(b)$f(x) = 1/x$，$C = [1, \infty)$：序列 2^k 逃向无穷远，目标值趋于紫色虚线 0。(c)$f(x) = x^2$（$x \neq 0$），$f(0) = 0.6$，$C = [-1, 1]$：序列 $1/k$ 趋于 0，目标值趋于 0，而 $f(0)$ 跳高到红点 0.6，值 0 无人取得。

(a) 中 $C = (0, 1]$ 有界但不闭，序列有极限 0，极限却被排除在外，第二关失败。(b) 中 $C = [1, \infty)$ 闭但无界，序列 2^k 没有收敛子列，第一关失败。(c) 中 $C = [-1, 1]$ 很好，序列也收敛到可行点 0，但函数在 0 处向上跳，极限处的值 0.6 高于序列目标值的极限 0，第三关失败。

第一关与第二关：紧性　在 $\mathbb{R}^n$ 中，有界闭集的每个序列都有收敛子列，而且子列的极限仍在集合内。这样的集合称为**紧集**（compact set）。紧性恰好一次通过前两关：有界让序列留得住，闭让极限合法。有界闭集的这一性质及一般度量空间中的紧致性，可参考卷四第 2 章“度量空间”。

第三关：只需要单向的比较　第三关若用连续性通过，得到的是熟悉的结论：有界闭集上的连续函数取得最小值。仔细看却会发现，连续性要求多

了。我们只需要极限处的值“不比序列高”，不需要它“等于序列的极限”。函数在极限点向下跳，只会让极限点更好；不能允许的是向上跳。

定义 1.6 下半连续 设 $\boldsymbol{C} \subseteq \mathbb{R}^n$，$f : \boldsymbol{C} \to \mathbb{R} \cup \{+\infty\}$。若对 $\boldsymbol{C}$ 中每个收敛到 $\boldsymbol{x} \in \boldsymbol{C}$ 的序列 $\boldsymbol{x}^{(k)}$，都有

$$f(\boldsymbol{x}) \le \liminf_{k\to\infty} f(\boldsymbol{x}^{(k)}), \tag{1.11}$$

就称 f 在 $\boldsymbol{C}$ 上**下半连续**（lower semicontinuous）。

连续函数满足这个条件且取等号。下半连续还可以用“高度不超过某个水平的部分”来刻画。对实数 a，称

$$\boldsymbol{S}_a = \{\boldsymbol{x} \in \boldsymbol{C} : f(\boldsymbol{x}) \le a\} \tag{1.12}$$

为 f 的**下水平集**（sublevel set），也就是地形图上高度不超过 a 的区域。

图 1.6比较两个只在 $x = 0$ 一点取值不同的函数。左边 $f(0) = 0.4$，取跳跃下方的值，下半连续，高度不超过 0.6 的点组成闭区间 $[0, 0.4]$。右边 $f(0) = 1$，取跳跃上方的值，不下半连续，同一个下水平集是 $(0, 0.4]$，缺了左端点。右边的函数沿 $x \downarrow 0$ 可以无限接近 0.4，却被 $x = 0$ 处的跳高挡住，最小值取不到。

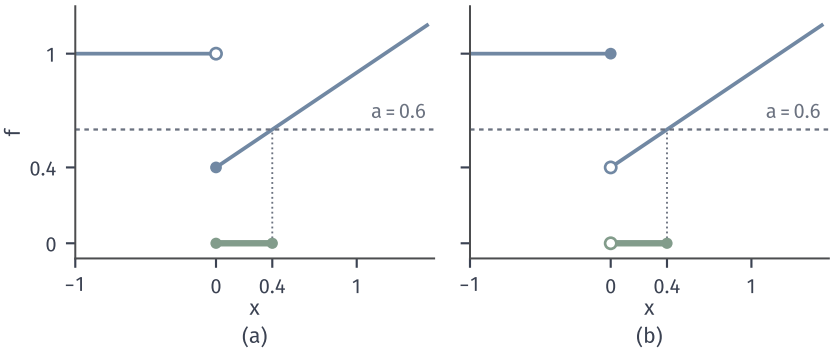


图 1.6 下半连续与下水平集的缺口。两个函数在 $x < 0$ 时都等于 1，在 $x > 0$ 时都等于 $0.4 + 0.5x$，实心蓝点是 $x = 0$ 处的函数值。灰色点线是水平 $a = 0.6$，绿色线段是下水平集 $\boldsymbol{S}_{0.6}$。(a)$f(0) = 0.4$，下半连续，下水平集是闭区间 $[0, 0.4]$。(b)$f(0) = 1$，向上跳，下水平集 $(0, 0.4]$ 缺少左端点。

图中的观察就是下面的引理：下半连续性的作用，是让下水平集不缺边界。

引理 1.7 下半连续与闭下水平集 设 $\boldsymbol{C} \subseteq \mathbb{R}^n$ 是闭集，$f : \boldsymbol{C} \to \mathbb{R} \cup \{+\infty\}$。$f$ 在 $\boldsymbol{C}$ 上下半连续，当且仅当对每个 $a \in \mathbb{R}$，下水平集 $\boldsymbol{S}_a$ 是闭集。

证明 先设 f 下半连续。取 $\boldsymbol{S}_a$ 中的序列 $\boldsymbol{x}^{(k)}$，设它收敛到 $\boldsymbol{x}$。$\boldsymbol{C}$ 是闭集，所以 $\boldsymbol{x} \in \boldsymbol{C}$。由下半连续性，

$$f(\boldsymbol{x}) \le \liminf_{k\to\infty} f(\boldsymbol{x}^{(k)}) \le a.$$

所以 $\boldsymbol{x} \in \boldsymbol{S}_a$，$\boldsymbol{S}_a$ 是闭集。

反过来，设每个 $\boldsymbol{S}_a$ 都是闭集，但 f 在某点 $\boldsymbol{x} \in \boldsymbol{C}$ 不满足式 (1.11)，即存在 $\boldsymbol{C}$ 中收敛到 $\boldsymbol{x}$ 的序列，使 $\liminf_k f(\boldsymbol{x}^{(k)}) < f(\boldsymbol{x})$。取实数 a 严格介于这两个量之间。下极限小于 a，所以有子列 $\boldsymbol{x}^{(k_j)}$ 始终满足 $f(\boldsymbol{x}^{(k_j)}) \le a$，也就是子列落在 $\boldsymbol{S}_a$ 中。

$\boldsymbol{S}_a$ 是闭集，子列的极限 $\boldsymbol{x}$ 也在其中，于是 $f(\boldsymbol{x}) \le a$。这与 $a < f(\boldsymbol{x})$ 矛盾。 ■

紧可行集上的存在定理 三关齐备，就得到第一个存在定理。

定理 1.8 紧可行集上的最小值 设 $\boldsymbol{C} \subseteq \mathbb{R}^n$ 非空且紧，$f : \boldsymbol{C} \to \mathbb{R} \cup \{+\infty\}$ 在 $\boldsymbol{C}$ 上下半连续，且至少有一点取有限值。则最优值 $f^\star$ 是有限实数，且最优解存在。

证明 由假设，$f^\star < +\infty$。取一个最小化序列 $\boldsymbol{x}^{(k)} \in \boldsymbol{C}$。$\boldsymbol{C}$ 是紧集，所以有子列 $\boldsymbol{x}^{(k_j)}$ 收敛到某个 $\boldsymbol{x}^\star \in \boldsymbol{C}$。由下半连续性，

$$f(\boldsymbol{x}^\star) \le \liminf_{j\to\infty} f(\boldsymbol{x}^{(k_j)}) = f^\star.$$

若 $f^\star = -\infty$，上式给出 $f(\boldsymbol{x}^\star) = -\infty$，与 f 不取 $-\infty$ 矛盾，所以 $f^\star$ 有限。又因 $\boldsymbol{x}^\star$ 可行，有 $f(\boldsymbol{x}^\star) \ge f^\star$。两个不等式合起来得到

$$f(\boldsymbol{x}^\star) = f^\star.$$

所以 $\boldsymbol{x}^\star$ 是最优解。 ■

资源分配的可行集由四个闭半平面相交而成，它有界且闭，目标是线性函数，因而连续。定理 1.8立刻保证最优解存在。这个结论不需要知道解在 $(2, 2)$，它只告诉我们值得去找。

定理的条件都是充分条件。例如 $f(x)=x^2$ 的可行集 $\mathbb{R}$ 无界，最小点 $x=0$ 依然存在。图 1.5的三个例子说明的是：逐条去掉条件后，结论可能不成立。

无界可行集：只看不太差的点　二次拟合的可行集是整个 $\mathbb{R}^n$，它不紧，定理 1.8不能直接用。但我们并不需要整个可行集紧，只需要把最小化序列关进某个紧集。取一个有限的水平 a，使下水平集 $\boldsymbol{S}_a$ 非空。凡是目标值高于 a 的点都比 $\boldsymbol{S}_a$ 中的点差，不可能是最优解，可以直接丢掉。剩下要看的只有 $\boldsymbol{S}_a$。

定理 1.9　紧下水平集保证存在　设 $f:\boldsymbol{C}\to\mathbb{R}\cup\{+\infty\}$ 在 $\boldsymbol{C}$ 上下半连续。若存在实数 a，使下水平集 $\boldsymbol{S}_a$ 非空且紧，则 $f^\star$ 是有限实数，且最优解存在。

证明　f 限制在紧集 $\boldsymbol{S}_a$ 上仍下半连续，并在 $\boldsymbol{S}_a$ 上取有限值。由定理 1.8，存在 $\boldsymbol{x}^\star\in\boldsymbol{S}_a$，使 $f(\boldsymbol{x}^\star)=\min_{\boldsymbol{S}_a} f\le a$。

对 $\boldsymbol{C}\setminus\boldsymbol{S}_a$ 中的点，有 $f(\boldsymbol{x})>a\ge f(\boldsymbol{x}^\star)$。所以 $\boldsymbol{x}^\star$ 是 f 在整个 $\boldsymbol{C}$ 上的最小点，$f^\star=f(\boldsymbol{x}^\star)$ 有限。 ■

这个定理只要求有一个下水平集紧，其余的下水平集可以无界。在 $\mathbb{R}$ 上考虑

$$f(x)=\frac{x^2}{1+x^2}.$$

令 $a=1/2$，解不等式 $f(x)\le 1/2$，得到 $x^2\le 1$，所以 $\boldsymbol{S}_{1/2}=[-1,1]$ 是紧集，最小点 $x=0$ 由此得到保证。而取 $a\ge 1$ 时，下水平集是整个 $\mathbb{R}$，无界。

怎样检验下水平集紧？闭性由引理 1.7给出，只要 $\boldsymbol{C}$ 闭、f 下半连续。有界性则需要目标在远处足够高，这就是强制性。

定义 1.10　强制性　设 $\boldsymbol{C}\subseteq\mathbb{R}^n$，$f:\boldsymbol{C}\to\mathbb{R}\cup\{+\infty\}$。若对 $\boldsymbol{C}$ 中任意满足 $\|\boldsymbol{x}^{(k)}\|_2\to\infty$ 的序列，都有 $f(\boldsymbol{x}^{(k)})\to+\infty$，就称 f 在 $\boldsymbol{C}$ 上是**强制的**（coercive）。

强制性等价于每个下水平集都有界。若某个 $\boldsymbol{S}_a$ 无界，从中取范数趋于无穷的序列，其目标值始终不超过 a，不满足强制性。反过来，若各下水平集都有界，而 $\|\boldsymbol{x}^{(k)}\|_2\to\infty$，则对任意 a，序列最终离开 $\boldsymbol{S}_a$，也就是最终 $f(\boldsymbol{x}^{(k)})>a$，所以 $f(\boldsymbol{x}^{(k)})\to+\infty$。

于是得到实际最常用的形式：若 $\boldsymbol{C}$ 非空闭，f 下半连续且强制，并在 $\boldsymbol{C}$ 上至少有一点取有限值，则最优解存在。这只需取 a 为该点的函数值，再

用定理 1.9。各条件的分工是：强制性使下水平集有界，留住了序列；$\boldsymbol{C}$ 闭与下半连续使下水平集闭，留住了极限。

回到二次拟合 对式 (1.3)逐项核对。f 是多项式，处处有限且连续；$\boldsymbol{C}=\mathbb{R}^n$ 是闭集。当 $\gamma>0$ 时，拟合项非负，所以

$$f(\boldsymbol{x})\geq\frac{\gamma}{2}\|\boldsymbol{x}\|_2^2.$$

范数趋于无穷时目标趋于无穷，f 强制，最优解存在。

$\gamma=0$ 时情况不同。对实例 (1.4)，沿方向 $(1,-1)$ 目标不变：取 $\boldsymbol{x}^{(k)}=(1+k,1-k)$，范数趋于无穷而 $f=0$，所以 f 不强制。图 1.7比较了两种情形，同一个水平 $a=1$ 的下水平集，在 $\gamma=0$ 时是无界的带，在 $\gamma=0.5$ 时收缩成一个椭圆。

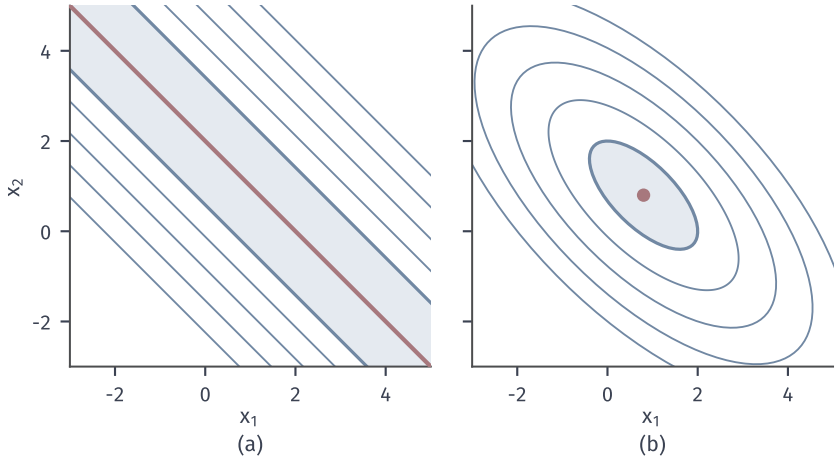


图 1.7 二次拟合实例 $f(\boldsymbol{x})=\frac{1}{2}(x_1+x_2-2)^2+\frac{\gamma}{2}\|\boldsymbol{x}\|_2^2$ 的下水平集。浅蓝区域及其粗边界是 $\{f\leq 1\}$，细线是其他等高线。(a)$\gamma=0$：下水平集是两条平行线之间的无界带，红线 $x_1+x_2=2$ 是最优解集合。(b)$\gamma=0.5$：下水平集是椭圆，红点是唯一最优解 $(0.8,0.8)$。

然而 $\gamma=0$ 时最优解仍然存在，整条直线 $x_1+x_2=2$ 都是。这再次说明强制性只是充分条件。对一般的 $\boldsymbol{A}$，不带正则项的最小二乘总有解，依据是正规方程 $\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{x}=\boldsymbol{A}^{\top}\boldsymbol{b}$ 总可解，可参考卷二第 11 章“线性方程与最小二乘的选解”，这里用不到强制性。

有限维的边界 整个论证依赖“有界闭集紧”，这是有限维空间的性质。平方可和的数列空间中，第 k 个坐标为 1、其余为 0 的数列组成一列单位向量，它们两两距离都是 $\sqrt{2}$，都在闭单位球里，却没有收敛子列。函数空间上的存在性要换一种收敛概念，第 29章会处理这件事；在 $\mathbb{R}^n$ 中，本节的定理已经够用。

1.1 优化问题的表述
1.2 最优解的存在
1.3 解的性质
1.4 最优解的判别
1.5 近似解的评价
1.6 本章小结

1.3 解的性质

知道解存在之后，自然要问这个解是什么样的：洼地的底部是不是最低处？最低点是不是只有一个？目标值接近最优时，位置也接近吗？这些问题都在比较两个候选，最简单的比较路径是连接它们的线段。本节一路沿线段比较，逐步加强要求，依次回答这三个问题。

凸集：线段留在里面 资源分配中，方案 $\boldsymbol{u}=(3,0)$ 与 $\boldsymbol{v}=(0,4)$ 都可行。各执行一半，得到混合方案 $\frac{1}{2}\boldsymbol{u}+\frac{1}{2}\boldsymbol{v}=(1.5,2)$，它也可行，因为 $1.5+2=3.5\le 4$，$3+2=5\le 6$，产量也非负。

这不是巧合。若 $\boldsymbol{u},\boldsymbol{v}$ 都满足同一个线性不等式 $\langle \boldsymbol{a},\boldsymbol{x}\rangle \le c$，则对 $\theta\in[0,1]$，

$$\langle \boldsymbol{a},\theta\boldsymbol{u}+(1-\theta)\boldsymbol{v}\rangle = \theta\langle \boldsymbol{a},\boldsymbol{u}\rangle + (1-\theta)\langle \boldsymbol{a},\boldsymbol{v}\rangle \le \theta c + (1-\theta)c = c.$$

可行方案任意混合仍然可行，这个性质值得单独命名。

定义 1.11 凸集 若对任意 $\boldsymbol{u},\boldsymbol{v}\in\boldsymbol{C}$ 与 $\theta\in[0,1]$，都有

$$\theta\boldsymbol{u}+(1-\theta)\boldsymbol{v}\in\boldsymbol{C}, \tag{1.13}$$

就称 $\boldsymbol{C}\subseteq\mathbb{R}^n$ 为**凸集**（convex set）。

几何上，凸集里任意两点之间的线段都留在集合内。上面的计算说明半空间 $\{\boldsymbol{x}:\langle \boldsymbol{a},\boldsymbol{x}\rangle\le c\}$ 是凸集。若干凸集的交仍是凸集：两点同时在每个集合中，线段也同时在每个集合中。资源分配的可行集是四个半空间的交，所以是凸集。图 1.8给出对照。

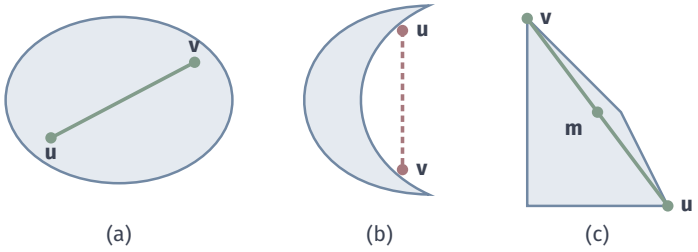


图 1.8 凸集与非凸集。(a) 椭圆盘中任意两点间的绿色线段留在集合内。(b) 月牙形中两点都在集合里，红色虚线却穿过缺口，所以不是凸集。(c) 资源分配的可行四边形，$\boldsymbol{u}=(3,0)$ 与 $\boldsymbol{v}=(0,4)$ 的等权混合 $\boldsymbol{m}=(1.5,2)$ 仍在集合内。

凸函数：图像不鼓过弦 可行集凸时，两个可行点之间的线段全是候选。接下来要求目标沿这条线段“不鼓起来”：线段上每一点的目标值，不超过两端目标值按相同权重的平均。

定义 1.12 凸函数 设 $\boldsymbol{C}$ 为凸集。若 $f:\boldsymbol{C}\to\mathbb{R}$ 对任意 $\boldsymbol{u},\boldsymbol{v}\in\boldsymbol{C}$ 与 $\theta\in[0,1]$ 满足

$$f\big(\theta\boldsymbol{u}+(1-\theta)\boldsymbol{v}\big)\le\theta f(\boldsymbol{u})+(1-\theta)f(\boldsymbol{v}),\tag{1.14}$$

就称 f 为 $\boldsymbol{C}$ 上的凸函数（convex function）。扩展实值函数称为凸函数，是指其有效定义域为凸集，且式 (1.14)对有效定义域中的点成立。

式 (1.14)右端是连接两点 $(\boldsymbol{u},f(\boldsymbol{u}))$ 与 $(\boldsymbol{v},f(\boldsymbol{v}))$ 的弦上的点，左端是同一位置的函数值。所以凸函数的图像位于每条弦的下方，也就是碗的形状。图 1.9(a) 是凸函数 $x^2/2$；(b) 中的函数有两个碗，连接两侧的弦从中间的鼓包下面穿过，不等式被破坏。对 $F=f+\iota_{\boldsymbol{C}}$，这个定义恰好要求 $\boldsymbol{C}$ 凸且 f 在 $\boldsymbol{C}$ 上凸。

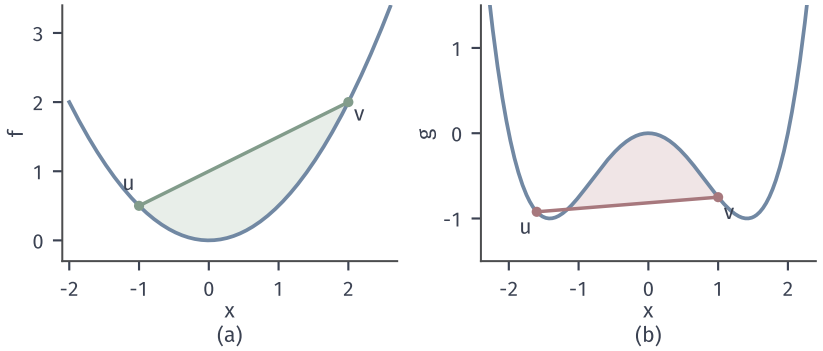


图 1.9 图像与弦。(a) 凸函数 $f(x)=x^2/2$，连接 $x=-1$ 与 $x=2$ 的绿色弦位于图像上方，浅绿区域是两者的间隔。(b) 非凸函数 $g(x)=x^4/4-x^2$，连接 $x=-1.6$ 与 $x=1$ 的红色弦有一段位于图像下方，浅红区域就是违反凸性的部分。

二次函数的情形可以算到底。设 $\boldsymbol{H}\in\mathbb{R}^{n\times n}$ 对称，考虑

$$q(\boldsymbol{x})=\frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{H}\boldsymbol{x}+\boldsymbol{a}^{\top}\boldsymbol{x}+a_0.$$

记 $\boldsymbol{w}=\theta\boldsymbol{u}+(1-\theta)\boldsymbol{v}$，我们计算弦与函数之间的间隔。线性项和常数项在加权平均中抵消，只需展开二次项：

$$\boldsymbol{w}^{\top}\boldsymbol{H}\boldsymbol{w}=\theta^2\boldsymbol{u}^{\top}\boldsymbol{H}\boldsymbol{u}+2\theta(1-\theta)\boldsymbol{u}^{\top}\boldsymbol{H}\boldsymbol{v}+(1-\theta)^2\boldsymbol{v}^{\top}\boldsymbol{H}\boldsymbol{v}.$$

用 $\theta-\theta^2=\theta(1-\theta)$，以及 $(1-\theta)-(1-\theta)^2=\theta(1-\theta)$，得到

$$\theta q(\boldsymbol{u})+(1-\theta)q(\boldsymbol{v})-q(\boldsymbol{w})=\frac{1}{2}\theta(1-\theta)(\boldsymbol{u}-\boldsymbol{v})^{\top}\boldsymbol{H}(\boldsymbol{u}-\boldsymbol{v}).\tag{1.15}$$

所以 q 凸当且仅当 $\boldsymbol{H}$ 半正定。

二次拟合目标 (1.3)展开后正是这种形式，其中 $\boldsymbol{H} = \boldsymbol{A}^{\top}\boldsymbol{A} + \gamma \boldsymbol{I}$。对任意 $\boldsymbol{w}$,

$$\boldsymbol{w}^{\top}\boldsymbol{H}\boldsymbol{w} = \|\boldsymbol{A}\boldsymbol{w}\|_2^2 + \gamma\|\boldsymbol{w}\|_2^2 \geq 0,$$

所以目标是凸函数。资源分配的目标是线性函数，式 (1.14)取等号，也是凸函数。

局部最优就是全局最优　现在回答第一个问题：山那边会不会有更深的谷。若目标和可行集都是凸的，答案是不会。

定理 1.13　凸问题的局部最优是全局最优　设 $\boldsymbol{C}$ 为凸集，$f : \boldsymbol{C} \to \mathbb{R}$ 为凸函数。则 f 在 $\boldsymbol{C}$ 上的每个局部最优解都是全局最优解，并且最优解集合是凸集。

证明　设 $\boldsymbol{u}$ 是局部最优解，对应的邻域半径为 r。假设存在 $\boldsymbol{v} \in \boldsymbol{C}$ 使 $f(\boldsymbol{v}) < f(\boldsymbol{u})$。对 $t \in (0,1)$，点 $\boldsymbol{u} + t(\boldsymbol{v} - \boldsymbol{u})$ 在线段上，所以属于 $\boldsymbol{C}$。由式 (1.14),

$$f\big(\boldsymbol{u} + t(\boldsymbol{v} - \boldsymbol{u})\big) \leq (1-t)f(\boldsymbol{u}) + tf(\boldsymbol{v}) < f(\boldsymbol{u}).$$

取 t 足够小，使 $t\|\boldsymbol{v} - \boldsymbol{u}\|_2 < r$，这个更低的点就落在 $\boldsymbol{C} \cap \boldsymbol{B}(\boldsymbol{u}, r)$ 中，与局部最优矛盾。所以 $\boldsymbol{u}$ 是全局最优解。

若 $\boldsymbol{u}, \boldsymbol{v}$ 都是最优解，线段上的点满足 $f \leq \theta f^{\star} + (1-\theta)f^{\star} = f^{\star}$，也是最优解，所以最优解集合是凸集。 ■

证明的几何意义是：如果远处有更低的点，连向它的弦从当前点一出发就下降，凸函数的图像又在弦下方，紧贴当前点就有更低的点。图 1.10用非凸的例子 1.4反过来看这件事：局部最优点 u 与更低的点 v 之间，弦在 u 的邻域里就低于 $f(u)$，而图像却在弦上方，浅红区域正是对凸性的违反。

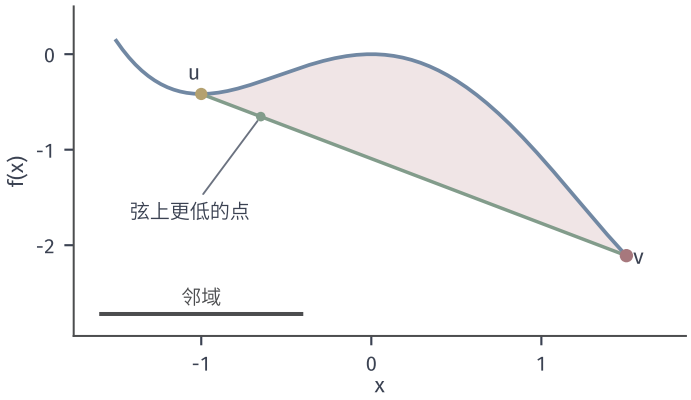


图 1.10 为什么凸问题没有假谷底。蓝线是 $f(x)=x^4/4-x^3/3-x^2$，黄点 $u=-1$ 是局部最优解，红点 $v=1.5$ 更低。绿色弦上紧靠 u 的点已经低于 $f(u)$，深灰线段是 u 的邻域。若 f 是凸函数，图像就必须在弦下方，u 的邻域里就有更低的点；浅红区域表明这里的 f 不是凸函数，u 才得以成为局部最优。

可行集和目标两个条件都要有。可行集不凸时，线段会跑出去：在 $C=[-3,-1]\cup[1,3]$ 上最小化凸函数 $(x-2)^2$，$x=-1$ 处的值是 9，它的邻域里的可行点都在 $[-3,-1]$ 中，函数值都不低于 9，所以它是局部最优解；全局最优解却是 $x=2$，值为 0。目标不凸时，例子 1.4已经给出反例。

严格凸与唯一性 凸性排除了假谷底，但没有排除平坦的谷底：$\gamma=0$ 的拟合实例沿直线 $x_1+x_2=2$ 处处最优。资源分配如果把利润改成 $2x_1+2x_2$，利润线就与边 $x_1+x_2=4$ 平行，从 $(0,4)$ 到 $(2,2)$ 的整条线段都最优。要让解唯一，需要弦和图像之间确实有间隔。

定义 1.14 严格凸函数 设 $\boldsymbol{C}$ 为凸集。若 $f:\boldsymbol{C}\to\mathbb{R}$ 对任意 $\boldsymbol{u}\neq\boldsymbol{v}$ 与 $\theta\in(0,1)$ 都使式 (1.14)严格成立，就称 f 为**严格凸函数**（strictly convex function）。

定理 1.15 严格凸目标至多有一个最小点 设 $\boldsymbol{C}$ 为凸集，f 在 $\boldsymbol{C}$ 上严格凸，则最优解至多有一个。若最优解存在，则它唯一。

证明 假设 $\boldsymbol{u}\neq\boldsymbol{v}$ 都是最优解。中点 $\frac{1}{2}(\boldsymbol{u}+\boldsymbol{v})\in\boldsymbol{C}$，由严格凸性，

$$f\Big(\frac{1}{2}(\boldsymbol{u}+\boldsymbol{v})\Big)<\frac{1}{2}f^\star+\frac{1}{2}f^\star=f^\star.$$

这与 $f^\star$ 是下确界矛盾。 ■

结论是“至多一个”，存在性要由上一节另外保证。正反两个方向都有反例。e^x 严格凸，却没有最小点，所以严格凸不推出存在。$|x|$ 有唯一最小点 0，但在 $[0,1]$ 上是线性的，式 (1.14)取等号，不严格凸，所以最小点唯一也不推出严格凸。资源分配更典型：线性目标毫无弯曲，解 $(2,2)$ 仍然唯一，唯一性来自可行集的顶点。

二次函数的严格凸性由式 (1.15)直接读出：$\boldsymbol{u}\neq\boldsymbol{v}$ 时间隔为正，当且仅当 $\boldsymbol{H}$ 正定。若 $\boldsymbol{H}$ 半正定但奇异，沿零空间方向的线段上间隔为零。对二次拟合，前面算出的二次型表明，$\gamma>0$ 或 $\boldsymbol{A}$ 列满秩时目标严格凸。

在实例 (1.4)中，二次型矩阵是

$$\boldsymbol{H}=\begin{bmatrix}1+\gamma & 1\\ 1 & 1+\gamma\end{bmatrix}.$$

$\gamma=0$ 时 $\boldsymbol{w}=(1,-1)$ 使 $\boldsymbol{w}^{\top}\boldsymbol{H}\boldsymbol{w}=0$，解成一条线。

$\gamma>0$ 时，唯一的解可以手算。记 $s=x_1+x_2$，由 $x_1^2+x_2^2\geq s^2/2$（等号当且仅当 $x_1=x_2$），得到

$$f(\boldsymbol{x})\geq\frac{1}{2}(s-2)^2+\frac{\gamma}{4}s^2.$$

右端是 s 的一元二次函数，令导数 $(s-2)+\gamma s/2$ 为零，得 $s=4/(2+\gamma)$。再取 $x_1=x_2=s/2$ 使等号成立，于是

$$\boldsymbol{x}^{\star}=\frac{2}{2+\gamma}(1,1),\qquad f^{\star}=\frac{2\gamma}{2+\gamma}. \tag{1.16}$$

例如 $\gamma=0.5$ 时，$\boldsymbol{x}^{\star}=(0.8,0.8)$，$f^{\star}=0.4$，这正是图 1.7(b) 中的红点。

强凸：间隔有多大　严格凸只说间隔为正，没说间隔有多大。取 $f(x)=x^4$，端点 $u=-t$，$v=t$，权重 $\theta=\frac{1}{2}$，弦中点的高度是 t^4，函数值是 0，所以间隔只有 t^4。而两点距离的平方是 $4t^2$。t 很小时，t^4 比 $4t^2$ 小得多。

间隔太小的后果是：目标值几乎相同的两个点可能相距很远，我们就无法从“目标值差不多最优”推断“位置差不多正确”。强凸性要求间隔至少与距离的平方成比例。

定义 1.16　强凸函数　设 $\boldsymbol{C}$ 为凸集，$\mu>0$。若对任意 $\boldsymbol{u},\boldsymbol{v}\in\boldsymbol{C}$ 与 $\theta\in[0,1]$，

$$\begin{aligned}f\big(\theta\boldsymbol{u}+(1-\theta)\boldsymbol{v}\big)\leq{}&\theta f(\boldsymbol{u})+(1-\theta)f(\boldsymbol{v})\\&-\frac{\mu}{2}\theta(1-\theta)\|\boldsymbol{u}-\boldsymbol{v}\|_2^2,\end{aligned} \tag{1.17}$$

> 就称 f 在 $\boldsymbol{C}$ 上是**强凸**（strongly convex）的，μ 称为**强凸常数**（strong convexity constant）。全卷用 μ 表示强凸常数。

与式 (1.15)比较，强凸性要求每条弦下方至少留出一个抛物线形的间隔。取 $\boldsymbol{H}=\mu\boldsymbol{I}$，式 (1.15)说明 $\frac{\mu}{2}\|\cdot\|_2^2$ 的弦间隔恰好是 $\frac{\mu}{2}\theta(1-\theta)\|\boldsymbol{u}-\boldsymbol{v}\|_2^2$。所以式 (1.17)等价于

$$f-\frac{\mu}{2}\|\cdot\|_2^2 \quad \text{是凸函数.} \tag{1.18}$$

直观上，强凸函数是一个凸函数再加上一只曲率为 μ 的碗。这个说法不要求可微：$x^2/2+|x-0.5|$ 减去 $x^2/2$ 后是凸函数，所以它是 1 强凸的，尽管在 $x=0.5$ 处不可微。

对二次函数，由式 (1.15)，q 是 μ 强凸的当且仅当

$$\boldsymbol{w}^{\top}\boldsymbol{H}\boldsymbol{w}\geq\mu\|\boldsymbol{w}\|_2^2 \qquad \text{对所有 } \boldsymbol{w} \text{ 成立.}$$

对称矩阵的二次型与特征值的关系给出最大的强凸常数 $\mu=\lambda_{\min}(\boldsymbol{H})$，这一关系可参考卷二第 6 章“谱分解”。

实例 (1.4)的 $\boldsymbol{H}$ 有特征值 γ（特征向量 $(1,-1)$）和 $2+\gamma$（特征向量 $(1,1)$），所以

$$\mu=\gamma.$$

正则系数恰好就是强凸常数。沿 $(1,-1)$ 方向，数据什么都没说，碗的弯曲全部来自正则项。

图 1.11把三种弯曲程度放在一起。(a) 中 $|x|$ 在 $[0.25,1]$ 上弦贴着图像，间隔为零。(b) 中 x^4 有间隔，但取 $t=0.5$ 时只有 0.0625，端点越靠近原点，它相对 t^2 越小。(c) 中 x^2 同样取 $t=0.5$，间隔是 $t^2=0.25$，对应 $\mu=2$ 时的下界 $\frac{\mu}{2}\cdot\frac{1}{4}\cdot 4t^2=t^2$，恰好取等。

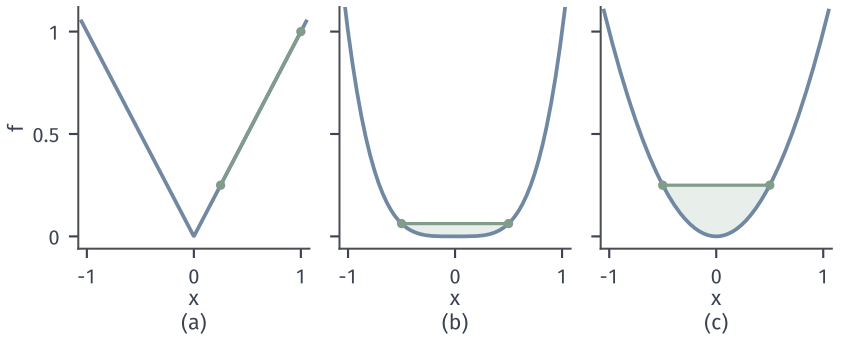


图 1.11　三种弯曲程度下的弦间隔，绿色线段是弦，浅绿区域是间隔。(a)$|x|$ 在同侧取端点时弦贴着图像，凸但不严格凸。(b)x^4 严格凸，端点 ±0.5 的中点处间隔只有 0.0625。(c)x^2 是 2 强凸的，同样端点的中点处间隔为 0.25。

目标差控制到解的距离　强凸性最直接的用途，是把目标值的误差换成位置的误差。

定理 1.17　强凸目标的二次增长　设 $\boldsymbol{C}$ 为凸集，f 在 $\boldsymbol{C}$ 上 μ 强凸，且最优解 $\boldsymbol{x}^\star$ 存在。则最优解唯一，并且对所有 $\boldsymbol{x}\in\boldsymbol{C}$，

$$f(\boldsymbol{x})-f^\star\ge\frac{\mu}{2}\|\boldsymbol{x}-\boldsymbol{x}^\star\|_2^2. \tag{1.19}$$

证明　对 $t\in(0,1)$，点 $\boldsymbol{x}^\star+t(\boldsymbol{x}-\boldsymbol{x}^\star)$ 在 $\boldsymbol{C}$ 中，目标值不低于 $f^\star$。在式 (1.17)中取 $\boldsymbol{u}=\boldsymbol{x}$，$\boldsymbol{v}=\boldsymbol{x}^\star$，$\theta=t$，得到

$$f^\star\le tf(\boldsymbol{x})+(1-t)f^\star-\frac{\mu}{2}t(1-t)\|\boldsymbol{x}-\boldsymbol{x}^\star\|_2^2.$$

移项后除以 $t>0$，得到

$$f(\boldsymbol{x})-f^\star\ge\frac{\mu}{2}(1-t)\|\boldsymbol{x}-\boldsymbol{x}^\star\|_2^2.$$

令 $t\downarrow 0$ 即得式 (1.19)。若 $\boldsymbol{x}$ 也是最优解，左端为零，迫使 $\boldsymbol{x}=\boldsymbol{x}^\star$。 ■

证明只用到可行集凸、目标强凸和最优解存在，没有假设解在内部或目标可微。把实例取 $\gamma=1$，由式 (1.16)，$\boldsymbol{x}^\star=(2/3,2/3)$，$\mu=1$。取 $\boldsymbol{x}=\boldsymbol{x}^\star+(1,-1)$，两个分量之和不变，所以拟合项不变，目标差全部来自正则项：

$$f(\boldsymbol{x})-f^\star=\frac{1}{2}\big(\|\boldsymbol{x}\|_2^2-\|\boldsymbol{x}^\star\|_2^2\big)=\frac{1}{2}\cdot 2=1.$$

距离的平方是 2，式 (1.19)的右端也是 1，在这里取等号，因为位移恰好沿最小特征值的方向。

可行集必须是凸的。x^2 在 $\mathbb{R}$ 上 2 强凸，但在 $C=\{x:|x|\ge 1\}$ 上有两个最小点 ±1，两点的目标差为 0，距离却是 2。证明中从 $\boldsymbol{x}^\star$ 走向 $\boldsymbol{x}$ 的线段离开了可行集，那一步就失效了。

表 1.2汇总本节的三级要求及各自多给出的结论。

目标（可行集凸）	弦下方的间隔	结论
凸	不小于 0	局部最优即全局最优，解集凸
严格凸	大于 0	解至多一个
μ 强凸	不小于二次量	解若存在则唯一，目标差控制距离

表 1.2　沿线段比较的三级要求。每一级都比上一级强，存在性仍需另外保证。

1.4 最优解的判别

1.1 优化问题的表述
1.2 最优解的存在
1.3 解的性质
1.4 最优解的判别
1.5 近似解的评价
1.6 本章小结

前面的条件都是整体性的：可行集是否紧、目标是否凸。实际计算时，我们手里只有一个候选点，以及它附近的函数值和导数。接下来要弄清：只看这一点的导数信息，能断定什么？不能断定什么？主线讨论无约束的光滑目标，或者可行集内部的点；最后说明受约束时情况怎样改变。

全卷用 $\nabla f(\boldsymbol{x})$ 表示梯度，$\nabla^2 f(\boldsymbol{x})$ 表示 Hessian 矩阵。多元函数的梯度、Hessian 和 Taylor 公式，可参考卷二第 20 章“多元函数微分”。

沿每个方向看　站在最低点上，朝任何方向迈一小步都不会更低。把这句话变成计算：固定点 $\bar{\boldsymbol{x}}$ 和方向 $\boldsymbol{d}$，只看沿这条直线的一元函数

$$\phi(t) = f(\bar{\boldsymbol{x}} + t\boldsymbol{d}).$$

链式法则给出它在 $t = 0$ 处的导数，即沿 $\boldsymbol{d}$ 的**方向导数**（directional derivative）：

$$\phi'(0) = \langle \nabla f(\bar{\boldsymbol{x}}), \boldsymbol{d} \rangle. \tag{1.20}$$

$\phi'(0) < 0$ 时，沿 $\boldsymbol{d}$ 走一小步目标下降，这样的 $\boldsymbol{d}$ 称为**下降方向**（descent direction）。条件 $\langle \nabla f(\bar{\boldsymbol{x}}), \boldsymbol{d} \rangle < 0$ 说明，只要梯度不为零，下降方向就占据整整半个空间，分界面与梯度垂直，也就是等高线在该点的切线。

用实例 (1.4)取 $\gamma = 0.5$ 算一次。梯度的两个分量是

$$\frac{\partial f}{\partial x_1} = x_1 + x_2 - 2 + \gamma x_1, \qquad \frac{\partial f}{\partial x_2} = x_1 + x_2 - 2 + \gamma x_2.$$

在 $\bar{\boldsymbol{x}} = (2, 0)$ 处，$\nabla f(\bar{\boldsymbol{x}}) = (1, 0)$。取 $\boldsymbol{d} = (-1, 1)$，由式 (1.20)，方向导数是 -1。

直接验证一下。沿这个方向 $x_1 + x_2$ 保持为 2，拟合项为零，于是

$$\phi(t) = \frac{1}{4}\big((2 - t)^2 + t^2\big), \qquad \phi'(0) = \frac{1}{4} \cdot (-4) = -1.$$

两种算法结果相同。图 1.12中，浅绿半平面是全部下降方向，竖直虚线是等高线在 $\bar{\boldsymbol{x}}$ 处的切线。负梯度方向 $-\nabla f$ 是其中的一个，$\boldsymbol{d}$ 是另一个，后者比负梯度更接近指向红色最优解的方向。

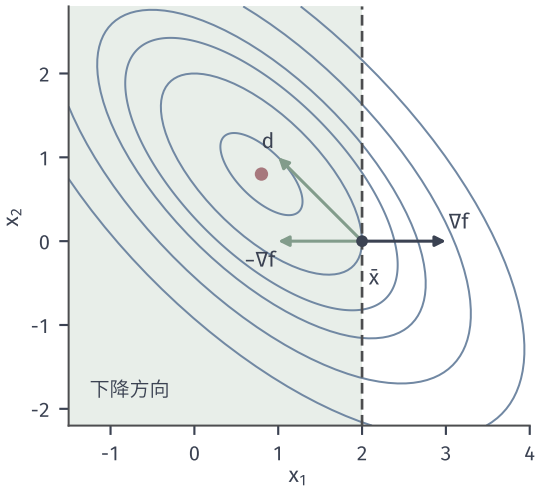


图 1.12　下降方向构成半平面。蓝线是 $f(\boldsymbol{x}) = \frac{1}{2}(x_1 + x_2 - 2)^2 + \frac{1}{4}\|\boldsymbol{x}\|_2^2$ 的等高线，$\bar{\boldsymbol{x}} = (2, 0)$ 处的梯度为 $(1, 0)$。竖直虚线与梯度垂直，浅绿区域的方向都满足 $\langle \nabla f(\bar{\boldsymbol{x}}), \boldsymbol{d} \rangle < 0$。绿色箭头是负梯度方向和 $\boldsymbol{d} = (-1, 1)$，红点是最优解 $(0.8, 0.8)$。

一阶必要条件　若 $\bar{\boldsymbol{x}}$ 是局部最优解，并且各个方向都可以走，就不能有下降方向。半个空间都是下降方向的唯一例外是梯度为零。为了让“各个方向都可以走”成立，下面要求点在可行集内部：称 $\bar{\boldsymbol{x}}$ 是 $\boldsymbol{C}$ 的**内点**（interior point），如果存在 $r > 0$ 使 $\boldsymbol{B}(\bar{\boldsymbol{x}}, r) \subseteq \boldsymbol{C}$。

定理 1.18　一阶必要条件　设 $\boldsymbol{x}^\star$ 是 $\boldsymbol{C}$ 的内点，f 在 $\boldsymbol{x}^\star$ 处可微。若 $\boldsymbol{x}^\star$ 是 f 在 $\boldsymbol{C}$ 上的局部最优解，则

$$\nabla f(\boldsymbol{x}^\star) = \boldsymbol{0}. \tag{1.21}$$

证明　任取方向 $\boldsymbol{d}$。$|t|$ 充分小时，$\boldsymbol{x}^\star + t\boldsymbol{d}$ 既在 $\boldsymbol{C}$ 内，又在局部最优的邻域内，所以 $\phi(t) = f(\boldsymbol{x}^\star + t\boldsymbol{d}) \geq \phi(0)$。

当 $t > 0$ 时，$(\phi(t) - \phi(0))/t \geq 0$。令 $t \downarrow 0$，由式 (1.20)得到

$$\langle \nabla f(\boldsymbol{x}^\star), \boldsymbol{d} \rangle \geq 0.$$

这对任意方向成立。取 $\boldsymbol{d} = -\nabla f(\boldsymbol{x}^\star)$，得到 $-\|\nabla f(\boldsymbol{x}^\star)\|_2^2 \geq 0$，所以梯度为零。 ■

梯度为零的点称为**驻点**（stationary point）。这个条件只是必要的，它在三处不能往下推。第一，驻点不一定是最小点：$x_1^2 - x_2^2$ 在原点有驻点，沿 x_1 轴是最低点，沿 x_2 轴是最高点，这样的驻点称为**鞍点**（saddle point）。第二，定理只管内点：例子 1.4的全局最优解 $x = 1.5$ 在边界上，导数不为零。第三，即使驻点是局部最优，也可能不是全局最优。

下面的二维例子同时展示这几点，后面会反复用到。考虑 $\mathbb{R}^2$ 上的

$$f(\boldsymbol{x}) = x_1^3 - 3x_1 + x_2^2. \tag{1.22}$$

令梯度为零：

$$\nabla f(\boldsymbol{x}) = (3x_1^2 - 3,\; 2x_2) = \boldsymbol{0}.$$

解得两个驻点 $(1,0)$ 和 $(-1,0)$。一阶信息到此为止，分不出这两个点的差别。

凸目标的驻点　凸性能把必要条件变成充分条件。关键在于：凸函数的图像不仅在弦下方，还在每一点切线的上方。切线只用到一个点的函数值和梯度，它若是全局下界，单点信息就能告诉我们远处的目标至少有多大。

定理 1.19　一阶支撑不等式　设 $\boldsymbol{D} \subseteq \mathbb{R}^n$ 是开凸集，$f : \boldsymbol{D} \to \mathbb{R}$ 可微。f 是凸函数，当且仅当对任意 $\boldsymbol{u}, \boldsymbol{v} \in \boldsymbol{D}$，

$$f(\boldsymbol{v}) \geq f(\boldsymbol{u}) + \langle \nabla f(\boldsymbol{u}), \boldsymbol{v} - \boldsymbol{u} \rangle. \tag{1.23}$$

证明　设 f 凸。对 $t \in (0,1]$，由式 (1.14)，

$$f\big(\boldsymbol{u} + t(\boldsymbol{v} - \boldsymbol{u})\big) \leq (1-t) f(\boldsymbol{u}) + t f(\boldsymbol{v}).$$

移项并除以 t，得到

$$\frac{f\big(\boldsymbol{u} + t(\boldsymbol{v} - \boldsymbol{u})\big) - f(\boldsymbol{u})}{t} \leq f(\boldsymbol{v}) - f(\boldsymbol{u}).$$

令 $t \downarrow 0$，左端趋于方向导数 $\langle \nabla f(\boldsymbol{u}), \boldsymbol{v} - \boldsymbol{u} \rangle$，即得式 (1.23)。

反过来，设式 (1.23)成立。取 $\boldsymbol{z} = \theta \boldsymbol{u} + (1-\theta)\boldsymbol{v}$，以 $\boldsymbol{z}$ 为切点，分别写出

$$f(\boldsymbol{u}) \geq f(\boldsymbol{z}) + \langle \nabla f(\boldsymbol{z}), \boldsymbol{u} - \boldsymbol{z} \rangle, \qquad f(\boldsymbol{v}) \geq f(\boldsymbol{z}) + \langle \nabla f(\boldsymbol{z}), \boldsymbol{v} - \boldsymbol{z} \rangle.$$

第一式乘 θ，第二式乘 $1-\theta$，再相加。由 $\boldsymbol{z}$ 的定义，

$$\theta(\boldsymbol{u} - \boldsymbol{z}) + (1-\theta)(\boldsymbol{v} - \boldsymbol{z}) = \boldsymbol{0},$$

所以内积项抵消，得到式 (1.14)。 ∎

图 1.13对比了两种情形。凸函数的切线（紫色）整条位于图像下方，是全局的下界。非凸函数在 $x = 0$ 处的水平切线则位于图像上方的一大段区域，单点信息不能给出下界。

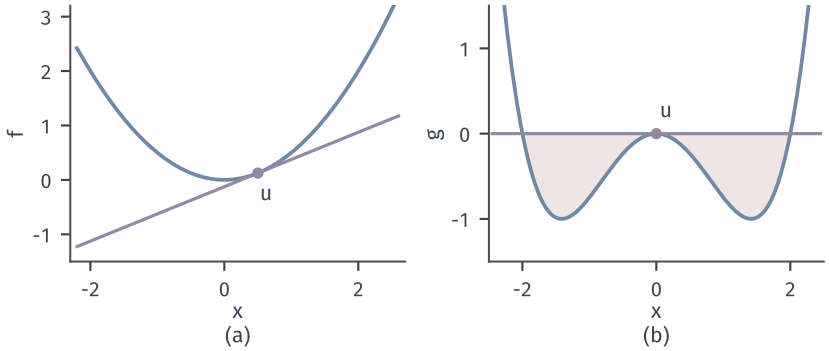


图 1.13 切线是否是全局下界。(a) 凸函数 $f(x)=x^2/2$ 在 $u=1/2$ 处的紫色切线整条位于图像下方。(b) 非凸函数 $g(x)=x^4/4-x^2$ 在 $u=0$ 处的切线是水平线，在 $0<|x|<2$ 时位于图像上方（浅红区域），不是下界。

把 $\nabla f(\boldsymbol{x}^\star)=\mathbf{0}$ 代入式 (1.23)，水平的切平面把最小值钉在切点上。

定理 1.20 凸目标驻点的全局最优性 设 $\boldsymbol{D}$ 是开凸集，$f:\boldsymbol{D}\to\mathbb{R}$ 凸且可微。则 $\boldsymbol{x}^\star\in\boldsymbol{D}$ 是 f 在 $\boldsymbol{D}$ 上的全局最优解，当且仅当 $\nabla f(\boldsymbol{x}^\star)=\mathbf{0}$。

证明 必要性来自定理 1.18，开集中每个点都是内点。充分性：若梯度为零，由式 (1.23)，对任意 $\boldsymbol{v}\in\boldsymbol{D}$，

$$f(\boldsymbol{v})\geq f(\boldsymbol{x}^\star)+\langle\mathbf{0},\boldsymbol{v}-\boldsymbol{x}^\star\rangle=f(\boldsymbol{x}^\star).$$

■

这个结论的价值在于：对凸目标，求解优化问题等价于解方程 $\nabla f=\mathbf{0}$，找到的任何一个解都是全局最优。二次拟合 (1.3)的梯度是

$$\nabla f(\boldsymbol{x})=\boldsymbol{A}^\top(\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b})+\gamma\boldsymbol{x}, \tag{1.24}$$

驻点条件就是正规方程

$$(\boldsymbol{A}^\top\boldsymbol{A}+\gamma\boldsymbol{I})\boldsymbol{x}=\boldsymbol{A}^\top\boldsymbol{b}.$$

实例中它化为

$$(1+\gamma)x_1+x_2=2,\qquad x_1+(1+\gamma)x_2=2.$$

两式相减得 $\gamma(x_1-x_2)=0$。$\gamma>0$ 时 $x_1=x_2$，解出的正是式 (1.16)；$\gamma=0$ 时两式都是 $x_1+x_2=2$，解成一条直线。

强凸函数还多一个二次项。设 f 可微且 μ 强凸。由式 (1.18)，$f-\frac{\mu}{2}\|\cdot\|_2^2$ 是凸函数，它的梯度是 $\nabla f(\boldsymbol{x})-\mu\boldsymbol{x}$。对它用式 (1.23)，其中多出的项可以合并：

$$\|\boldsymbol{v}\|_2^2-\|\boldsymbol{u}\|_2^2-2\langle\boldsymbol{u},\boldsymbol{v}-\boldsymbol{u}\rangle=\|\boldsymbol{v}-\boldsymbol{u}\|_2^2.$$

于是得到

$$f(\boldsymbol{v})\geq f(\boldsymbol{u})+\langle\nabla f(\boldsymbol{u}),\boldsymbol{v}-\boldsymbol{u}\rangle+\frac{\mu}{2}\|\boldsymbol{v}-\boldsymbol{u}\|_2^2. \tag{1.25}$$

这个不等式顺便补上了强凸目标的存在性。在 $\mathbb{R}^n$ 上取 $\boldsymbol{u}=\boldsymbol{0}$，由柯西不等式，

$$f(\boldsymbol{v})\geq f(\boldsymbol{0})-\|\nabla f(\boldsymbol{0})\|_2\|\boldsymbol{v}\|_2+\frac{\mu}{2}\|\boldsymbol{v}\|_2^2.$$

右端在 $\|\boldsymbol{v}\|_2\to\infty$ 时趋于 $+\infty$，所以 f 强制。可微函数连续，由上一节的结论，最优解存在。再由定理 1.17，最优解唯一。

二阶条件：曲率区分驻点的类型 一阶条件分不清极小、极大与鞍点，因为驻点处梯度项消失了，函数的变化由下一阶主导。设 f 二阶连续可微，$\nabla f(\boldsymbol{x}^\star)=\boldsymbol{0}$。由带 Lagrange 余项的 Taylor 公式，对小的 $\boldsymbol{h}$，存在 $s\in(0,1)$ 使

$$f(\boldsymbol{x}^\star+\boldsymbol{h})-f(\boldsymbol{x}^\star)=\frac{1}{2}\boldsymbol{h}^\top\nabla^2 f(\boldsymbol{x}^\star+s\boldsymbol{h})\boldsymbol{h}. \tag{1.26}$$

量 $\boldsymbol{d}^\top\nabla^2 f(\boldsymbol{x}^\star)\boldsymbol{d}$ 是函数沿 $\boldsymbol{d}$ 方向的曲率：为正时向上弯，为负时向下弯。

定理 1.21 二阶条件 设 $\boldsymbol{x}^\star$ 是 $\boldsymbol{C}$ 的内点，f 在 $\boldsymbol{x}^\star$ 附近二阶连续可微。

1. 必要条件：若 $\boldsymbol{x}^\star$ 是局部最优解，则 $\nabla f(\boldsymbol{x}^\star)=\boldsymbol{0}$ 且 $\nabla^2 f(\boldsymbol{x}^\star)$ 半正定。
2. 充分条件：若 $\nabla f(\boldsymbol{x}^\star)=\boldsymbol{0}$ 且 $\nabla^2 f(\boldsymbol{x}^\star)$ 正定，则 $\boldsymbol{x}^\star$ 是严格局部最优解。

证明 记 $\boldsymbol{H}=\nabla^2 f(\boldsymbol{x}^\star)$。先证必要条件，一阶部分即定理 1.18。假设某个 $\boldsymbol{d}$ 使 $\boldsymbol{d}^\top\boldsymbol{H}\boldsymbol{d}<0$。由 Hessian 的连续性，$|t|$ 充分小时，对所有 $s\in(0,1)$ 都有

$$\boldsymbol{d}^\top\nabla^2 f(\boldsymbol{x}^\star+st\boldsymbol{d})\boldsymbol{d}<0.$$

在式 (1.26)中取 $\boldsymbol{h}=t\boldsymbol{d}$，就得到 $f(\boldsymbol{x}^\star+t\boldsymbol{d})<f(\boldsymbol{x}^\star)$，与局部最优矛盾。

再证充分条件。记 $\lambda_{\min}>0$ 为 $\boldsymbol{H}$ 的最小特征值，于是

$$\boldsymbol{h}^\top\boldsymbol{H}\boldsymbol{h}\geq\lambda_{\min}\|\boldsymbol{h}\|_2^2.$$

由 Hessian 的连续性，取足够小的 $r > 0$，使 $\boldsymbol{B}(\boldsymbol{x}^\star, r) \subseteq \boldsymbol{C}$，并且 $\|\boldsymbol{h}\|_2 < r$ 时

$$\left\|\nabla^2 f(\boldsymbol{x}^\star + \boldsymbol{h}) - \boldsymbol{H}\right\|_2 \leq \frac{\lambda_{\min}}{2}.$$

这样对 $\|\boldsymbol{h}\|_2 < r$ 和任意 $s \in (0,1)$，二次型至多比 $\boldsymbol{h}^{\mathsf{T}}\boldsymbol{H}\boldsymbol{h}$ 小 $\frac{\lambda_{\min}}{2}\|\boldsymbol{h}\|_2^2$。代入式 (1.26)，对 $\boldsymbol{h} \neq \boldsymbol{0}$，

$$f(\boldsymbol{x}^\star + \boldsymbol{h}) - f(\boldsymbol{x}^\star) \geq \frac{1}{2}\left(\lambda_{\min} - \frac{\lambda_{\min}}{2}\right)\|\boldsymbol{h}\|_2^2 = \frac{\lambda_{\min}}{4}\|\boldsymbol{h}\|_2^2 > 0.$$

所以 $\boldsymbol{x}^\star$ 是严格局部最优解。 ■

回到式 (1.22)。它的 Hessian 是

$$\nabla^2 f(\boldsymbol{x}) = \begin{bmatrix} 6x_1 & 0 \\ 0 & 2 \end{bmatrix}.$$

在 $(1,0)$ 处是 $\mathrm{diag}(6,2)$，正定，所以这是严格局部最优解，函数值为 -2。在 $(-1,0)$ 处是 $\mathrm{diag}(-6,2)$，不定，不是局部最优解，也不是局部极大点，而是鞍点，函数值为 2。

二阶条件到此仍是局部结论。沿 $x_1 \to -\infty$，$f \to -\infty$，所以这个问题无下界，局部最优点 $(1,0)$ 远不是全局最优。图 1.14中，穿过鞍点的粗等高线围出一个“盆”，$(1,0)$ 在盆底，翻过鞍点向左，地面一路下降。

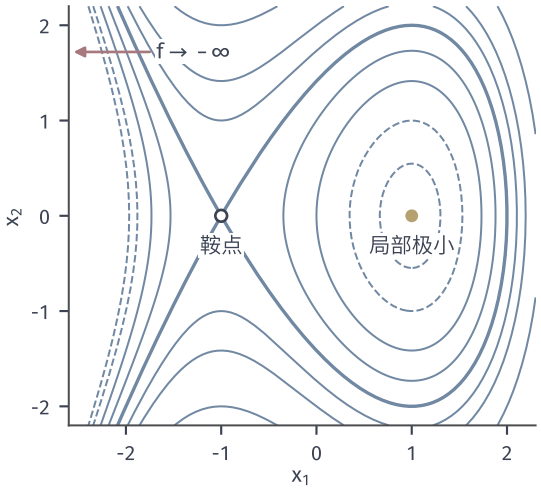


图 1.14 $f(\boldsymbol{x}) = x_1^3 - 3x_1 + x_2^2$ 的等高线，虚线是负值水平。黄点 $(1,0)$ 是严格局部最优解，空心点 $(-1,0)$ 是鞍点，粗线是穿过鞍点的等高线 $f = 2$。红色箭头所指的左侧目标趋于 $-\infty$，所以局部最优解不是全局最优解。

要从局部曲率得到整体结论，就得要求曲率处处非负，这正是凸性的二阶判据。

定理 1.22 凸性的二阶判据 设 $\boldsymbol{D} \subseteq \mathbb{R}^n$ 是开凸集，$f : \boldsymbol{D} \to \mathbb{R}$ 二阶连续可微。则 f 凸当且仅当 $\nabla^2 f(\boldsymbol{x})$ 在 $\boldsymbol{D}$ 上处处半正定；f 是 μ 强凸的当且仅当 $\nabla^2 f(\boldsymbol{x}) - \mu \boldsymbol{I}$ 在 $\boldsymbol{D}$ 上处处半正定。

证明 设 f 凸，取 $\boldsymbol{x} \in \boldsymbol{D}$ 和方向 $\boldsymbol{h}$。t 充分小时，由式 (1.23)和带 Lagrange 余项的 Taylor 公式，存在 $s \in (0,1)$ 使

$$0 \le f(\boldsymbol{x}+t\boldsymbol{h}) - f(\boldsymbol{x}) - t\langle \nabla f(\boldsymbol{x}), \boldsymbol{h}\rangle = \frac{t^2}{2}\boldsymbol{h}^{\top}\nabla^2 f(\boldsymbol{x}+st\boldsymbol{h})\boldsymbol{h}.$$

除以 $t^2/2$，令 $t \to 0$，由 Hessian 的连续性得到 $\boldsymbol{h}^{\top}\nabla^2 f(\boldsymbol{x})\boldsymbol{h} \ge 0$。

反过来，设 Hessian 处处半正定。对 $\boldsymbol{u}, \boldsymbol{v} \in \boldsymbol{D}$，令 $\psi(t) = f(\boldsymbol{u} + t(\boldsymbol{v}-\boldsymbol{u}))$，则 $\psi'' \ge 0$。由带 Lagrange 余项的 Taylor 公式，

$$\psi(1) = \psi(0) + \psi'(0) + \frac{1}{2}\psi''(\xi) \ge \psi(0) + \psi'(0),$$

这正是式 (1.23)，由定理 1.19，f 凸。

强凸的情形，把上述结论用于 $f - \frac{\mu}{2}\|\cdot\|_2^2$，它的 Hessian 是 $\nabla^2 f - \mu \boldsymbol{I}$，再用式 (1.18)。 ■

判据要求在整个开凸集上成立，只在单个点检查不能证明函数凸。式 (1.22)在 $(1,0)$ 处 Hessian 正定，但在 $x_1 < 0$ 处有负特征值，所以它不是凸函数，局部最优也就不必是全局最优。二次拟合的 Hessian 处处等于 $\boldsymbol{A}^{\top}\boldsymbol{A} + \gamma \boldsymbol{I}$，半正定，这与前面用弦算出的结论一致。

退化驻点：二阶也判不了 定理 1.21的两个条件之间留有缺口：Hessian 半正定但奇异时，必要条件满足，充分条件不满足，二阶信息不足以判断。这样的驻点称为**退化驻点**（degenerate stationary point）。

函数 $x_1^2 + x_2^4$ 和 $x_1^2 + x_2^3$ 在原点的梯度都为零，Hessian 都是 $\operatorname{diag}(2,0)$，二阶信息完全相同。前者对 $\boldsymbol{x} \neq \boldsymbol{0}$ 恒为正，原点是严格最小点，说明正定不是必要的。后者沿 $(0,-t)$ 取值 $-t^3 < 0$，原点不是局部最优解，说明半正定不是充分的。

决定结果的是 x_2 方向的高阶项，这正是 Hessian 在零特征方向上看不到的信息。图 1.15中，请注意红色区域是否碰到原点：碰到就说明任意小的邻域里都有更低的点。(c) 与 (d) 的二阶信息相同，红色区域却一有一无。

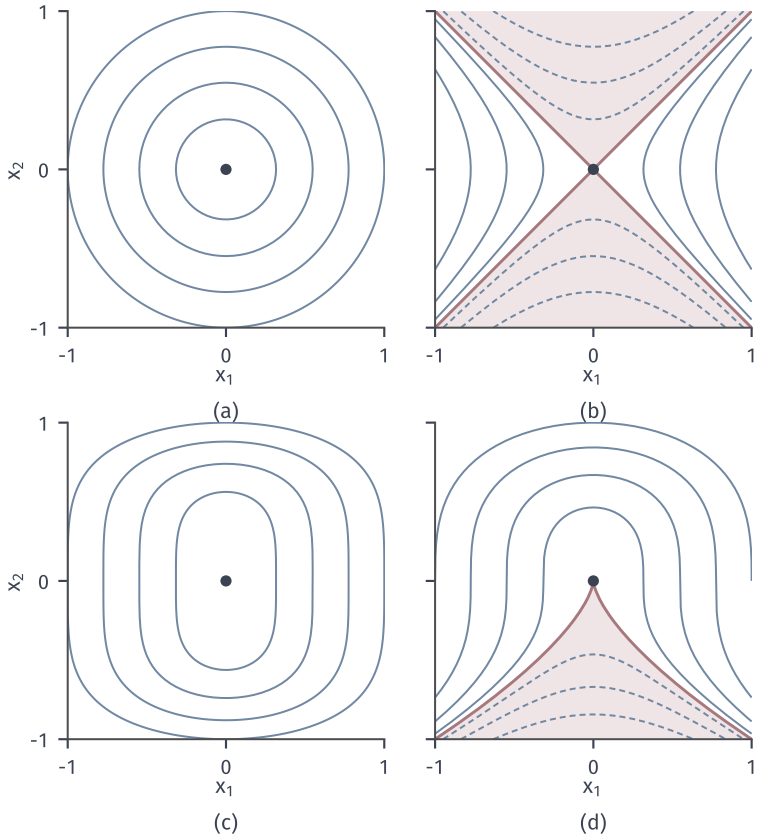


图 1.15 原点处四种驻点的等高线，浅红区域是函数值低于 $f(\mathbf{0})=0$ 的点，虚线是负值水平，红线是零等高线。(a)$x_1^2+x_2^2$，Hessian 正定，严格最小点。(b)$x_1^2-x_2^2$，Hessian 不定，鞍点。(c)$x_1^2+x_2^4$，Hessian 为 diag(2,0)，仍是严格最小点。(d)$x_1^2+x_2^3$，Hessian 同为 diag(2,0)，但原点下方有更低的点，不是局部最优解。

负曲率方向 定理 1.21必要性的证明还包含一条可以操作的信息。若驻点处存在方向 $\boldsymbol{d}$ 使 $\boldsymbol{d}^{\top}\nabla^2 f(\boldsymbol{x}^{\star})\boldsymbol{d}<0$，就称 $\boldsymbol{d}$ 为**负曲率方向**（negative curvature direction）。沿它走，一阶变化为零，目标却以二次速度下降。

对 $f(\boldsymbol{x})=x_1^2-x_2^2$，Hessian 是 diag(2,−2)。沿单位方向 $\boldsymbol{d}$，

$$f(t\boldsymbol{d})=\frac{t^2}{2}\boldsymbol{d}^{\top}\operatorname{diag}(2,-2)\boldsymbol{d}=t^2(d_1^2-d_2^2).$$

图 1.16取三个方向：$\boldsymbol{d}_1=(1,0)$ 曲率为 2，向上弯；$\boldsymbol{d}_2=(1,1)/\sqrt{2}$ 曲率为 0，二阶项恰好消失；$\boldsymbol{d}_3=(0,1)$ 曲率为 −2，向下弯。站在鞍点上，梯度指不出任何下降方向，Hessian 的负特征向量却指出了一条。怎样利用这一点离开鞍点，由第 10章讨论。

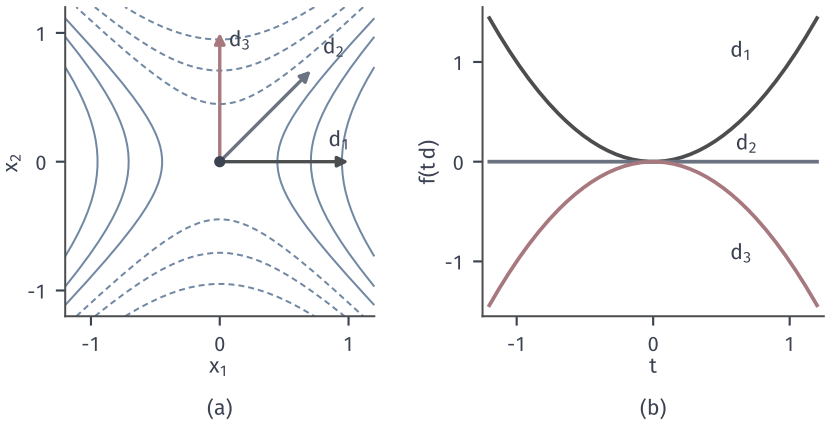


图 1.16 鞍点处不同方向的曲率。(a)$f(\boldsymbol{x}) = x_1^2 - x_2^2$ 的等高线（虚线为负值）与三个单位方向。(b) 沿这三个方向的一元限制 $f(t\boldsymbol{d})$：$\boldsymbol{d}_1$ 向上弯，$\boldsymbol{d}_2$ 保持为零，红色的 $\boldsymbol{d}_3$ 向下弯，是负曲率方向。

表 1.3整理到目前为止的判别依据。阅读时要注意“必要”与“充分”的方向，以及结论是局部的还是全局的。

依据	性质	能得到的结论
$\nabla f = \mathbf{0}$	内点局部最优的必要条件	排除非驻点
$\nabla f = \mathbf{0}$，$\nabla^2 f \succeq \mathbf{0}$	局部最优的必要条件	进一步排除负曲率点
$\nabla f = \mathbf{0}$，$\nabla^2 f \succ \mathbf{0}$	充分条件，非必要	严格局部最优
$\nabla f = \mathbf{0}$，目标凸	充要条件	全局最优

表 1.3 无约束光滑目标的判别依据。前三行只看一个点，第四行需要目标的整体性质。

受约束时允许的方向变了 一阶条件的证明要求 $\boldsymbol{d}$ 和 $-\boldsymbol{d}$ 都能走。在边界上这个前提不成立，能走的方向变少，要求也相应放宽。称 $\boldsymbol{d}$ 是 $\bar{\boldsymbol{x}} \in \boldsymbol{C}$ 处的**可行方向**（feasible direction），如果 $t > 0$ 充分小时 $\bar{\boldsymbol{x}} + t\boldsymbol{d} \in \boldsymbol{C}$。重复定理 1.18证明的前半段，只用 $t > 0$，就得到：若 $\boldsymbol{x}^\star$ 是局部最优解，f 在该点可微，则对每个可行方向 $\boldsymbol{d}$，

$$\langle \nabla f(\boldsymbol{x}^\star), \boldsymbol{d} \rangle \geq 0. \tag{1.27}$$

用资源分配验证。在 $\boldsymbol{x}^\star = (2, 2)$ 处，两条资源约束取等号，$\boldsymbol{d}$ 可行当且仅当它不增加这两个约束，即

$$d_1 + d_2 \leq 0, \qquad 2d_1 + d_2 \leq 0.$$

1.1　优化问题的表述
1.2　最优解的存在
1.3　解的性质
1.4　最优解的判别
1.5　近似解的评价
1.6　本章小结

目标的梯度是 $(-3,-2)$，不等于零。方向导数却可以拆开：

$$\langle \nabla f(\boldsymbol{x}^\star), \boldsymbol{d} \rangle = -3d_1 - 2d_2 = -(d_1 + d_2) - (2d_1 + d_2) \geq 0.$$

这里的拆分仍然是第 1.1节那个“两条约束相加”。图 1.17显示了几何含义：$-\nabla f$ 指向利润增大的方向，它伸出了可行集，而所有绿色的可行方向都和它成钝角或直角。所以 $(2,2)$ 处梯度不为零，却没有“既可行又下降”的方向。

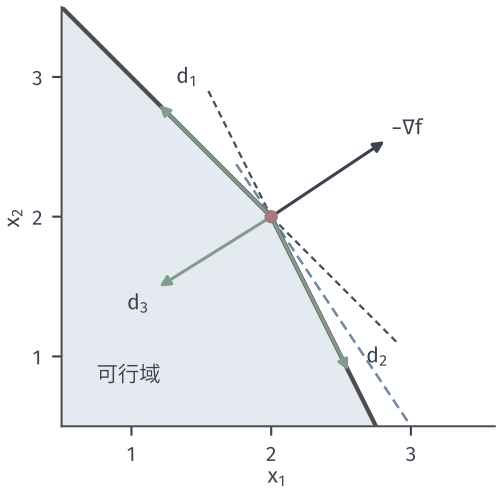


图 1.17　边界上的最优点梯度不必为零。红点是资源分配的最优解 $(2,2)$，深灰粗线是两条取等号的约束，蓝色虚线是过该点的等目标线。绿色箭头是可行方向，全部可行方向都夹在 $\boldsymbol{d}_1 = (-1,1)$ 与 $\boldsymbol{d}_2 = (1,-2)$ 之间。$-\nabla f = (3,2)$ 伸出可行集，与每个可行方向的内积都不为正。

若 $\boldsymbol{C}$ 凸、f 在包含 $\boldsymbol{C}$ 的开凸集上凸且可微，式 (1.27)对每个 $\boldsymbol{d} = \boldsymbol{y} - \boldsymbol{x}^\star$（$\boldsymbol{y} \in \boldsymbol{C}$）成立时，代入式 (1.23)就得到 $f(\boldsymbol{y}) \geq f(\boldsymbol{x}^\star)$，所以它也是充分的。

式 (1.27)还不是一个能直接检验的判据。可行方向可能有无穷多个，曲线边界上甚至可能一个非零的都没有：单位圆周上，沿任何直线都会立刻离开圆周。把它写成关于约束函数的代数条件需要新工具，第 17章在明确约束之后建立这些判别。

1.5　近似解的评价

前四节讨论的是精确的解。实际计算几乎从不交出精确解：迭代在有限步后停止，浮点运算带来舍入。这就需要回答：拿到一个近似解，怎样说清它好到什么程度？我们会看到，“好”有几种不同的含义，它们回答不同的问题，只在一定条件下可以换算。

算法交出什么 后面各章的方法都产生一列点。全卷用带括号的上标表示迭代步：$\boldsymbol{x}^{(t)}$ 是第 t 步的点，$t = 0, 1, \dots, T$，T 是总步数。括号把迭代编号与幂区分开，元素下标仍写在下面，如 $x_i^{(t)}$。多数方法每一步沿某个方向走一段：

$$\boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} + \alpha^{(t)} \boldsymbol{d}^{(t)}, \tag{1.28}$$

其中 $\boldsymbol{d}^{(t)}$ 是方向，$\alpha^{(t)} > 0$ 是步长。当前点的梯度和 Hessian 简记为 $\boldsymbol{g}^{(t)} = \nabla f(\boldsymbol{x}^{(t)})$ 与 $\boldsymbol{H}^{(t)} = \nabla^2 f(\boldsymbol{x}^{(t)})$。

算法最后报告的点记为 $\hat{\boldsymbol{x}}$。本节不关心它怎样得到，只关心怎样评价。要注意 $\hat{\boldsymbol{x}}$ 与 $\boldsymbol{x}^\star$ 的区别：前者是算法的输出，手里实实在在有；后者是问题的解，我们通常不知道。

目标差 最直接的指标是目标差

$$e_f(\hat{\boldsymbol{x}}) = f(\hat{\boldsymbol{x}}) - f^\star. \tag{1.29}$$

它回答“这个结果比最好的结果差多少”。可行点的目标差非负；若 $\hat{\boldsymbol{x}}$ 可行且 $e_f(\hat{\boldsymbol{x}}) \le \varepsilon$，就称它为 ε 最优解（ε-optimal solution）。

目标差的麻烦在于 $f^\star$ 通常未知。但只要有一个下界 $\ell \le f^\star$，就有可以计算的上界 $e_f(\hat{\boldsymbol{x}}) \le f(\hat{\boldsymbol{x}}) - \ell$。资源分配中，“两条约束相加”给出了下界 $\ell = -10$，它不依赖于解出 $(2, 2)$。对可行点 $\hat{\boldsymbol{x}} = (1.5, 2)$，利润是 8.5，因此

$$f(\hat{\boldsymbol{x}}) - \ell = -8.5 - (-10) = 1.5.$$

这正是上下界夹逼的用处：不知道解在哪里，也能确认当前结果至多差 1.5。这样的下界怎样系统地构造，是第 18章的主题。

解距离 第二个指标问位置差多远。设最优解集合 $\boldsymbol{S}$ 非空，定义到解集的距离

$$e_d(\hat{\boldsymbol{x}}) = \operatorname{dist}(\hat{\boldsymbol{x}}, \boldsymbol{S}) = \inf_{\boldsymbol{x} \in \boldsymbol{S}} \|\hat{\boldsymbol{x}} - \boldsymbol{x}\|_2. \tag{1.30}$$

解唯一时，它就是 $\|\hat{\boldsymbol{x}} - \boldsymbol{x}^\star\|_2$。

解不唯一时要注意参照对象。实例 (1.4)取 $\gamma = 0$，点 $(11, -9)$ 在直线 $x_1 + x_2 = 2$ 上，它本身就是最优解，到解集的距离为 0。若心里的“正确系数”是 $(1, 1)$，两者却相距 $\|(10, -10)\|_2 \approx 14.1$。把解距离写成到某一个解的距离，就在问题没有提供信息的地方提了要求。

梯度大小 前两个指标都含有未知量，第三个可以直接算：

$$e_g(\hat{\boldsymbol{x}}) = \|\nabla f(\hat{\boldsymbol{x}})\|_2. \tag{1.31}$$

由第 1.4节，无约束时局部最优解的梯度为零，所以梯度大小可以作为一种缺口的度量。满足 $e_g(\hat{\boldsymbol{x}}) \le \varepsilon$ 的点称为 ε 驻点（ε-stationary point）。

梯度小却不等于接近解。图 1.18(a) 比较 $f_1(x) = 0.005x^2$ 与 $f_2(x) = 0.5x^2$，两者的最小点都是 0。在 $x = 10$ 处 $f_1' = 0.1$，在 $x = 0.1$ 处 $f_2' = 0.1$，梯度一样大。前者的目标差是 0.5，距离是 10；后者分别是 0.005 和 0.1。原因在曲率：f_1 的二阶导数只有 0.01，地形太平，坡度很小时离谷底仍然很远。

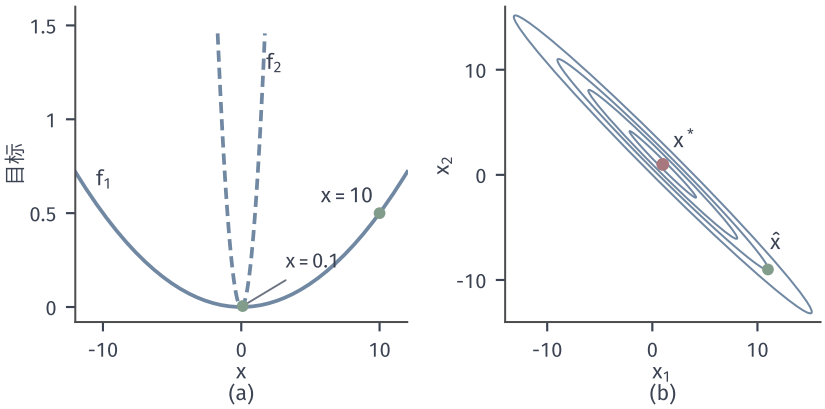


图 1.18　小梯度与小误差。(a) 平坦的 $f_1(x) = 0.005x^2$（实线）在 $x = 10$ 处与陡峭的 $f_2(x) = 0.5x^2$（虚线）在 $x = 0.1$ 处导数都是 0.1，目标差和距离却相差约两个量级。(b) 拟合实例取 $\gamma = 0.01$，蓝线是目标差等于 $0.1, 0.5, 1, 2$ 的等高线，沿 $(1, -1)$ 方向被拉得极长。绿点 $\hat{\boldsymbol{x}} = (11, -9)$ 的梯度大小约为 0.142，到红点 $\boldsymbol{x}^\star$ 的距离约为 14.1。

二维的情形更说明问题。实例 (1.4)取 $\gamma = 0.01$，由式 (1.16)，解和最优值是

$$\boldsymbol{x}^\star \approx (0.995, 0.995), \qquad f^\star \approx 0.00995.$$

取 $\hat{\boldsymbol{x}} = (11, -9)$。两分量之和为 2，拟合项为零，于是目标值和梯度分别是

$$f(\hat{\boldsymbol{x}}) = 0.005 \cdot (121 + 81) = 1.01, \qquad \nabla f(\hat{\boldsymbol{x}}) = (0.11, -0.09).$$

三个指标的数值是

$$e_f \approx 1.000, \qquad e_d \approx 14.14, \qquad e_g \approx 0.142.$$

观测已经完美拟合，梯度也不大，点却在长沟里离解很远。图 1.18(b) 的长沟就是强凸常数 $\mu = 0.01$ 很小的样子。

驻点还有另一重不足：非凸目标的驻点可以根本不是局部最优解。式 (1.22)的鞍点 $(-1, 0)$ 梯度为零，$e_g = 0$，而这个问题甚至没有下界。所以“算法找到驻点”和“算法找到解”是两个强度不同的结论。

三种指标的容差集合 把三个指标都限定在同一个 ε 以内，得到三个不同形状的区域。以二次目标为例，记位移 $\boldsymbol{w} = \boldsymbol{x} - \boldsymbol{x}^\star$。由 $\nabla f(\boldsymbol{x}^\star) = \boldsymbol{0}$，三个区域分别是

$$\frac{1}{2}\boldsymbol{w}^{\top}\boldsymbol{H}\boldsymbol{w} \le \varepsilon, \qquad \|\boldsymbol{w}\|_2 \le \varepsilon, \qquad \|\boldsymbol{H}\boldsymbol{w}\|_2 \le \varepsilon.$$

图 1.19取实例 $\gamma = 0.1$，$\varepsilon = 0.1$。圆很小；目标差的椭圆沿平坦方向半轴为 $\sqrt{2\varepsilon/\gamma} \approx 1.41$；梯度的椭圆沿平坦方向半轴为 $\varepsilon/\gamma = 1$，沿陡峭方向只有 $\varepsilon/(2+\gamma) \approx 0.048$。

三个区域互不包含，所以“达到精度 ε”必须说明用的是哪个指标。沿平坦方向，目标差和梯度都很宽容；沿陡峭方向，梯度最严格。

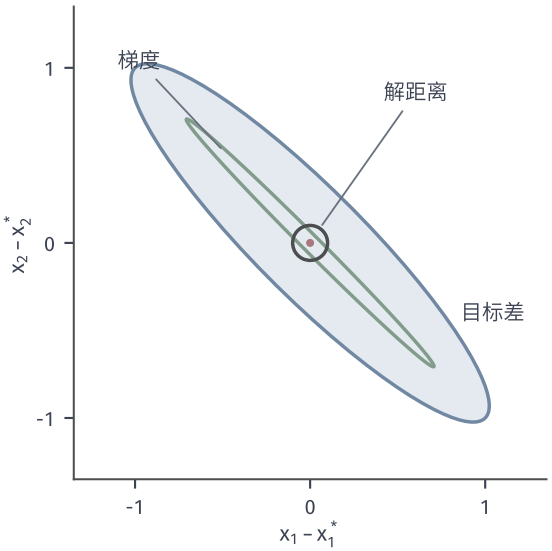


图 1.19 同一个 $\varepsilon = 0.1$ 下三种指标的容差集合，横纵轴是相对于 $\boldsymbol{x}^\star$ 的位移，目标取 $\gamma = 0.1$ 的拟合实例，$\boldsymbol{H}$ 的特征值为 0.1 和 2.1。蓝色椭圆内目标差不超过 ε，绿色椭圆内梯度大小不超过 ε，深灰色小圆内解距离不超过 ε。

换算的条件：曲率的上下界 前面的例子都指向曲率。把它变成定量结论，需要两个常数：曲率的下界 μ 和上界 L。全卷用 L 表示光滑常数，用 $\kappa = L/\mu$ 表示条件数。这里先在二阶可微的情形下引入，用 $\boldsymbol{A} \preceq \boldsymbol{B}$ 表示 $\boldsymbol{B} - \boldsymbol{A}$ 半正定。第 5章将把 L 推广到只要求梯度 Lipschitz 连续的函数。

定理 1.23 三种误差的换算 设 $f : \mathbb{R}^n \to \mathbb{R}$ 二阶连续可微，且存在 $0 < \mu \le L$，使对所有 $\boldsymbol{x}$，

$$\mu \boldsymbol{I} \preceq \nabla^2 f(\boldsymbol{x}) \preceq L\boldsymbol{I}. \tag{1.32}$$

则 f 有唯一最优解 $\boldsymbol{x}^\star$，并且对任意 $\boldsymbol{x}$，

$$\begin{gathered}\frac{\mu}{2}e_d^2 \le e_f \le \frac{L}{2}e_d^2, \qquad \mu e_d \le e_g \le L e_d, \\ \frac{1}{2L}e_g^2 \le e_f \le \frac{1}{2\mu}e_g^2.\end{gathered} \tag{1.33}$$

证明 由定理 1.22，f 是 μ 强凸的，由第 1.4节的结论，最优解存在且唯一。记 $\boldsymbol{w} = \boldsymbol{x} - \boldsymbol{x}^\star$，$e_d = \|\boldsymbol{w}\|_2$。

第一组：由式 (1.26)，存在 $s \in (0,1)$ 使

$$e_f = \frac{1}{2}\boldsymbol{w}^{\mathrm{T}}\nabla^2 f(\boldsymbol{x}^\star + s\boldsymbol{w})\boldsymbol{w}.$$

再用式 (1.32)夹住二次型，即得。

第二组：由 $\nabla f(\boldsymbol{x}^\star) = \boldsymbol{0}$ 和微积分基本定理，

$$\nabla f(\boldsymbol{x}) = \boldsymbol{B}\boldsymbol{w}, \qquad \boldsymbol{B} = \int_0^1 \nabla^2 f(\boldsymbol{x}^\star + s\boldsymbol{w})\,\mathrm{d}s.$$

$\boldsymbol{B}$ 对称，其二次型是被积函数二次型的积分，所以特征值都在 $[\mu, L]$ 内，于是

$$\mu\|\boldsymbol{w}\|_2 \le \|\boldsymbol{B}\boldsymbol{w}\|_2 \le L\|\boldsymbol{w}\|_2.$$

第三组的右半：在式 (1.25)中取 $\boldsymbol{u} = \boldsymbol{x}$，右端是 $\boldsymbol{v}$ 的二次函数，在 $\boldsymbol{v} = \boldsymbol{x} - \nabla f(\boldsymbol{x})/\mu$ 处最小。所以对所有 $\boldsymbol{v}$，

$$f(\boldsymbol{v}) \ge f(\boldsymbol{x}) - \frac{1}{2\mu}\|\nabla f(\boldsymbol{x})\|_2^2.$$

取 $\boldsymbol{v} = \boldsymbol{x}^\star$ 即得 $e_f \le e_g^2/(2\mu)$。

第三组的左半：由 Taylor 公式和 $\nabla^2 f \preceq L\boldsymbol{I}$，对任意 $\boldsymbol{p}$ 有

$$f(\boldsymbol{x}+\boldsymbol{p}) \le f(\boldsymbol{x}) + \langle \nabla f(\boldsymbol{x}), \boldsymbol{p}\rangle + \frac{L}{2}\|\boldsymbol{p}\|_2^2.$$

取 $\boldsymbol{p} = -\nabla f(\boldsymbol{x})/L$，得到

$$f^\star \le f\Big(\boldsymbol{x} - \frac{1}{L}\nabla f(\boldsymbol{x})\Big) \le f(\boldsymbol{x}) - \frac{1}{2L}\|\nabla f(\boldsymbol{x})\|_2^2.$$

移项即得 $e_f \ge e_g^2/(2L)$。 ■

图 1.20把式 (1.33)画成一张换算图，每条箭头表示“已知箭尾的量，可以控制箭头的量”。凡用到 μ 的箭头，都是从目标值或梯度推断位置，需

要下弯曲率；用到 L 的箭头，是从位置推断目标值或梯度，需要上弯曲率有限。

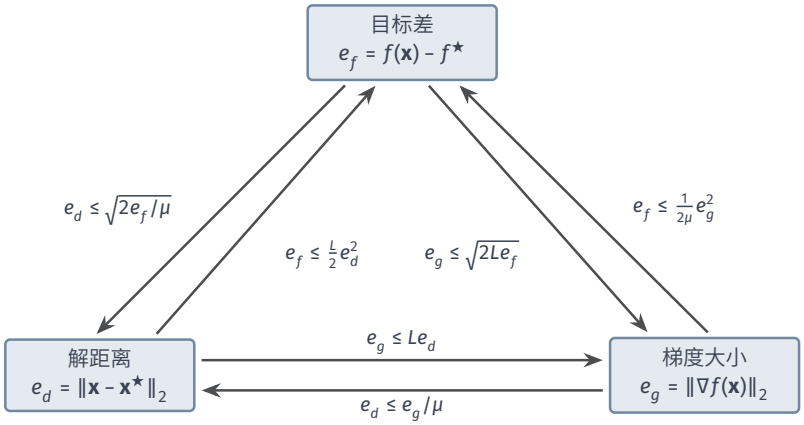


图 1.20　无约束时三种误差的换算，条件是 $\mu \boldsymbol{I} \preceq \nabla^2 f \preceq L\boldsymbol{I}$。箭头从已知量指向被控制的量。可计算的只有右下角的梯度大小，它指向其余两个量的两条箭头都依赖 μ。

用 $\gamma = 0.01$ 的实例代入。此时 $\mu = 0.01, L = 2.01, \kappa = 201$。对 $\hat{\boldsymbol{x}} = (11, -9)$，右半边的两个上界是

$$e_f \le \frac{e_g^2}{2\mu} \approx \frac{0.0202}{0.02} = 1.01, \qquad e_d \le \frac{e_g}{\mu} \approx 14.2.$$

实际值是 1.000 和 14.14，两个界都很贴近，因为 $\hat{\boldsymbol{x}} - \boldsymbol{x}^\star$ 几乎沿着平坦方向。而梯度约 0.142 这个数看起来很小，放大 $1/\mu = 100$ 倍后才是真实的距离。

两个常数不能互相替代，缺了一个，相应的箭头就断了。μ 接近零时，梯度几乎不提供关于目标差和距离的信息。L 不存在时，距离小也不能保证梯度小：$|x|$ 在任意靠近 0 的点 $x \neq 0$ 处，梯度大小都是 1。κ 大表示两个方向的曲率差得远，同一个 e_d 对应的 e_g 可以相差 κ 倍。

有约束时：可行性　定理 1.23只针对无约束问题。有约束时，算法的输出可能不满足约束，目标差本身也就失去了意义。用**可行性残差**（feasibility residual）度量违反的程度：

$$r_{\text{feas}}(\hat{\boldsymbol{x}}) = \max\Big\{\max_i \ \max\{g_i(\hat{\boldsymbol{x}}), 0\},\ \max_j |h_j(\hat{\boldsymbol{x}})|\Big\}. \tag{1.34}$$

可行点的残差为零，残差大于零的点违反了至少一条约束。

资源分配中取点 $\tilde{\boldsymbol{x}} = (2.1, 2)$，它违反了两条资源约束：

$$g_1(\tilde{\boldsymbol{x}}) = 0.1, \qquad g_2(\tilde{\boldsymbol{x}}) = 0.2, \qquad r_{\text{feas}}(\tilde{\boldsymbol{x}}) = 0.2.$$

它的利润是 10.3，比最优利润还高，也就是 $f(\tilde{\boldsymbol{x}}) - f^\star = -0.3 < 0$。多出来的利润并不是好事，它来自多用的资源。把两条约束相加的论证用在这里，利润至多超出 $g_1 + g_2 = 0.3$，恰好等于 0.3。

反过来，可行点 $(0,0)$ 的残差为零，利润却是 0，目标差为 10。图 1.21中，绿点可行但利润不足，红叉利润过高但不可行。所以只报告目标值或只报告可行性都不够，两者要一起报告。

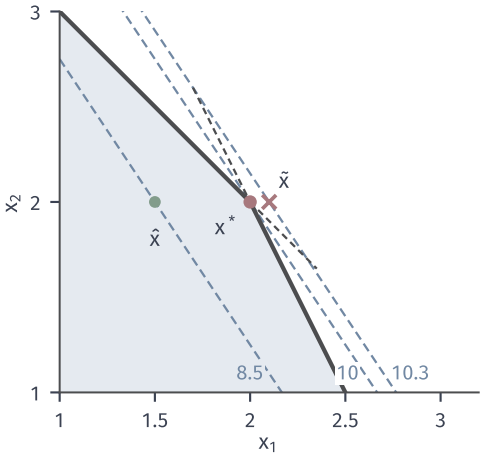


图 1.21 目标值与可行性要一起看。浅蓝区域是资源分配的部分可行集，蓝色虚线旁的数字是利润。绿点 $\hat{\boldsymbol{x}} = (1.5, 2)$ 可行，利润 8.5；红点 $\boldsymbol{x}^\star = (2, 2)$ 是最优解，利润 10；红叉 $\tilde{\boldsymbol{x}} = (2.1, 2)$ 利润 10.3，高于最优值，但违反了两条资源约束。

约束的数值量纲也影响残差。把“工时”的单位换成分钟，同一条约束乘以 60，残差也放大 60 倍，可行集却没有变。比较之前要先把约束的尺度说清楚。

有约束时：最优性残差 第 1.4节的图 1.17说明，有约束时梯度大小不再是合适的度量：最优解处的梯度不必为零。**最优性残差**（optimality residual）指这样一类量：在当前点可以计算，并且恰好在一阶条件成立时为零。无约束时它就是梯度大小。

一个能手算的情形是盒约束 $\boldsymbol{C} = \{\boldsymbol{x} : l_i \le x_i \le u_i\}$，上下界允许取无穷。记 $\Pi_{\boldsymbol{C}}$ 为逐坐标截断到 $[l_i, u_i]$ 的投影，定义

$$\boldsymbol{r}(\boldsymbol{x}) = \boldsymbol{x} - \Pi_{\boldsymbol{C}}\big(\boldsymbol{x} - \nabla f(\boldsymbol{x})\big). \tag{1.35}$$

逐坐标看，记 g_i 为此处的第 i 个偏导数：x_i 严格在区间内部时，$r_i = 0$ 要求 $g_i = 0$；$x_i = l_i$ 时，$r_i = 0$ 只要求 $g_i \ge 0$；$x_i = u_i$ 时，只要求 $g_i \le 0$。这正是可行方向条件 (1.27)逐坐标的写法。

取实例 $\gamma = 0.5$，加约束 $x_1 \ge 1.2$。解在边界上：固定 $x_1 = 1.2$，对 x_2 最小化得 $x_2 = 8/15$，点 $\boldsymbol{x}^\star = (1.2, 8/15)$。此处的梯度由式 (1.24)算得

$$\nabla f(\boldsymbol{x}^\star) = \Big(\frac{1}{3},\ 0\Big).$$

梯度不为零，但第一个坐标在下界上，偏导数非负，$\boldsymbol{r}(\boldsymbol{x}^\star) = \mathbf{0}$。这个问题是凸的，由上一节的充分性，$\boldsymbol{x}^\star$ 确实是最优解。

再看一个不是解的可行点 $\hat{\boldsymbol{x}} = (1.5, 0.5)$。此处 $\nabla f(\hat{\boldsymbol{x}}) = (0.75, 0.25)$，先走一步再截断：

$$\hat{\boldsymbol{x}} - \nabla f(\hat{\boldsymbol{x}}) = (0.75, 0.25), \qquad \Pi_{\boldsymbol{C}}(0.75, 0.25) = (1.2, 0.25).$$

所以 $\boldsymbol{r}(\hat{\boldsymbol{x}}) = (0.3, 0.25)$，范数约为 0.39。这个残差告诉我们，点还没有满足一阶条件。

一般约束的最优性残差要用到约束梯度的组合，由第 17章建立；非光滑目标没有梯度，相应的量由第 11章定义。这里只需记住它的职责：在不知道解的情况下，度量当前点离一阶条件还差多少。

精度标准　表 1.4汇总这些指标。后续各章陈述结果时，都要说清用的是哪一个。

阈值的取法也要交代。绝对标准 $e_g \le \varepsilon$ 依赖目标的尺度：把 f 整体乘以 100，解不变，梯度却放大 100 倍，同一个 ε 的严格程度就变了。所以实践中常用相对标准，例如

$$\|\boldsymbol{g}^{(t)}\|_2 \le \varepsilon \, \max\{1, \|\boldsymbol{g}^{(0)}\|_2\}. \tag{1.36}$$

评价方法与决定停止是两种场合。比较方法时，常对同一问题先用高精度方法算出参照值 $f^\star$，再看目标差随计算量的变化；参照值本身也有误差，应当说明怎样得到。实际求解时 $f^\star$ 未知，只能依据可计算的残差决定何时停止，而残差小对目标差意味着什么，取决于 μ 这样的条件。

指标	回答的问题	能否直接计算	换算所需条件
目标差 e_f	结果比最好差多少	需要 $f^\star$ 或其下界	可行点；μ 可换成距离，L 可换成梯度
解距离 e_d	位置差多远	需要解集	解不唯一时参照解集；L 可换成目标差和梯度
梯度大小 e_g	局部还有多少下降余地	能	无约束；μ 才能换成目标差和距离
可行性残差 r_{feas}	违反约束多少	能	依赖约束的尺度
最优性残差	离一阶条件还差多少	能	凸问题中才对应全局最优

表 1.4　近似解的评价指标。前三项针对无约束或已知可行的点，后两项用于约束问题；换算条件的含义见定理 1.23。

1.1 优化问题的表述
1.2 最优解的存在
1.3 解的性质
1.4 最优解的判别
1.5 近似解的评价
1.6 本章小结

最后要区分算法的结论。说“迭代收敛到驻点”“输出满足 $e_g \le \varepsilon$”“输出是 ε 最优解”，是三个强度依次上升的陈述，中间隔着凸性或曲率下界这样的条件。迭代次数与每步代价怎样计入比较，由第 5章规定。

1.6 本章小结

本章把“在允许的选择里找最好的”拆成了几个分别回答的问题。写一个优化问题要同时给出决策变量、目标函数和可行集。最优值是下确界，最优解是取得它的可行点，两者可以分离：问题可能不可行、无下界，或最优值有限却未被达到。局部最优只和附近的可行点比较，全局最优和所有可行点比较。约束指标函数把约束并入目标而不改变问题，普通指示函数和有限惩罚则不能这样用。

存在性靠最小化序列的三关：留得住、极限合法、比较传得到。紧性通过前两关，下半连续通过第三关，无界可行集用紧下水平集或强制性处理。解的性质靠线段比较：凸性使局部最优成为全局最优，严格凸使解至多一个，强凸使目标差控制到解的距离。

判别依赖一个点的导数信息。一阶和二阶条件在内点上区分驻点、局部最优和鞍点，它们本身是局部的；只有目标凸时，驻点才是全局最优。边界上的最优点梯度可以不为零，因为允许的方向变少了。

两个贯穿的例子展示了这些问题怎样得到回答。资源分配的可行集是有界多面体，解存在；把两条资源约束相加，同时得到下界和达到它的点 $(2,2)$。二次拟合的 $\gamma > 0$ 让目标强制，又让 Hessian 正定，解存在且唯一，目标差可以换成距离；$\gamma = 0$ 且 $\boldsymbol{A}$ 秩亏时，目标不再强制，解仍存在，却成了一条直线。

表 1.5汇总各结论所需的条件，表中均为充分条件，反例列说明去掉条件或反向推断时的后果。

算法的输出和问题的解是两回事。输出 $\hat{\boldsymbol{x}}$ 由目标差、解距离、梯度大小、可行性残差和最优性残差分别衡量，它们回答不同的问题，只有在曲率上下界这样的条件下才能换算，系数随 $1/\mu$ 放大。

本章没有构造任何算法。从下一章起，线性规划把这些语言用在最具体的模型上：可行集是多面体，解在顶点中寻找，“给约束配权重再相加”发展成可以核对的最优性证书。

问题	充分条件	结论	反例或边界
最优解是否存在	可行集非空紧，目标下半连续且有有限值；或某个下水平集非空紧	最优值有限且被达到	$(0,1]$ 上的 x；$[1,\infty)$ 上的 $1/x$；在 0 处跳高的函数
局部是否即全局	可行集凸，目标凸	局部最优解都是全局最优解，解集凸	例子中的四次函数；$[-3,-1]\cup[1,3]$ 上的 $(x-2)^2$
解是否唯一	可行集凸，目标严格凸，解存在	解唯一	e^x 严格凸而无最小点；$\lvert x\rvert$ 与资源分配有唯一解而不严格凸
目标差能否换成距离	可行集凸，目标 μ 强凸，解存在	$f(\boldsymbol{x})-f^\star \ge \frac{\mu}{2}\lVert\boldsymbol{x}-\boldsymbol{x}^\star\rVert_2^2$	非凸可行集 $\{\lvert x\rvert\ge 1\}$ 上的 x^2
内点能否用梯度判别	可微；开凸集上目标凸	局部最优必有 $\nabla f=\mathbf{0}$；凸时 $\nabla f=\mathbf{0}$ 即全局最优	鞍点；边界最优点的导数可不为零
驻点是否局部最优	二阶连续可微，Hessian 正定	严格局部最优解	$x_1^2+x_2^4$（正定非必要）；$x_1^2+x_2^3$（半正定不充分）
小梯度是否表示小误差	$\mu\boldsymbol{I}\preceq\nabla^2 f\preceq L\boldsymbol{I}$，无约束	$e_f\le e_g^2/(2\mu)$，$e_d\le e_g/\mu$	平坦目标 $0.005x^2$；$\gamma=0.01$ 的拟合实例

表 1.5　本章主要问题、充分条件与边界。

2.1 线性规划的表述
2.2 基本可行解
2.3 线性规划的对偶
2.4 线性松弛
2.5 本章小结

第 2 章

线性规划

第 1章的车间每天有 4 个工时、6 份原料，生产两种产品，利润是 $3x_1+2x_2$。我们画出可行的四边形，看到等利润线最后擦过角点 $(2,2)$，又把两条约束相加，得到利润不超过 10 的上界。这个小例子里同时出现了三件事：候选点虽有无穷多个，答案却落在角上；答案对不对，可以靠一个不等式当场核实；产量如果只能取整数，还要另外考虑。

线性规划（linear programming，LP）研究目标和约束都是线性函数的优化问题。变量一多就画不出图，上面三件事都要改用线性代数来说。第 2.1节把资源配置、网络流这些不同来源的模型写成同一种标准形式。第 2.2节把“角点”翻译成矩阵的语言，并回答在什么条件下最优解一定能在角点取得。

第 2.3节从“给约束配权重”出发，构造一个与原问题配对的问题，它提供的下界与最优值恰好相等，于是最优性有了可以独立核对的证据。第 2.4节考虑变量必须取整数的情形，说明去掉整数要求后的连续问题能提供什么，又不能提供什么。

2.1 线性规划的表述

来源不同的线性模型，怎样写成同一种形式，使后面的定理和计算只需要处理这一种形式？我们先看资源配置和网络流两个模型，它们的约束长得很不一样；然后规定标准型，并逐项说明改写时什么保持不变、什么发生了变化。

资源配置　车间问题可以这样一般化。有 n 种产品和 m 种资源，产品 j 的产量是 x_j，单位利润是 p_j，每生产一单位消耗资源 i 的量是 $A_{i,j}$，资源 i 的总量是 b_i。最大利润的产量由下面的问题决定：

$$\max_{\boldsymbol{x}\in\mathbb{R}^n} \ \boldsymbol{p}^{\top}\boldsymbol{x} \quad \text{s.t.} \quad \boldsymbol{A}\boldsymbol{x}\le\boldsymbol{b}, \quad \boldsymbol{x}\ge\boldsymbol{0}. \tag{2.1}$$

向量之间的不等号表示逐分量成立，$\boldsymbol{x} \geq \mathbf{0}$ 就是每个分量非负。车间问题对应 $n = m = 2$，数据是

$$\boldsymbol{A} = \begin{bmatrix} 1 & 1 \\ 2 & 1 \end{bmatrix}, \qquad \boldsymbol{b} = \begin{bmatrix} 4 \\ 6 \end{bmatrix}, \qquad \boldsymbol{p} = \begin{bmatrix} 3 \\ 2 \end{bmatrix}. \tag{2.2}$$

第一行是工时，第二行是原料。

这个模型能写成线性形式，靠的是两条假设。一是比例：产量加倍，利润和消耗都加倍。二是可加：两种产品的利润和消耗直接相加，互不影响。如果批量大了原料打折，单位消耗就依赖产量，约束里会出现 $x_1 x_2$ 或 x_1^2 这样的项，模型就不再是线性的。

> **定义 2.1　线性规划**　在 $\mathbb{R}^n$ 中，以一个线性函数为目标，在有限个线性等式和非严格线性不等式的约束下求最小值或最大值，这样的问题称为线性规划。

定义只允许非严格不等式。若允许 $x < 2$ 这样的约束，在其上最大化 x，上确界 2 就取不到，这正是第 1章区分过的“下确界未达到”。非严格不等式和等式都定义闭集，这类麻烦在线性规划里不会由约束的开边界引起。

网络流　第二个模型的约束是等式。图 2.1是一个有 4 个节点、5 条有向弧的网络，每条弧旁的数字是运送一单位货物的费用。节点 1 要运出 1 单位货物，节点 4 要收到 1 单位，节点 2, 3 只中转。

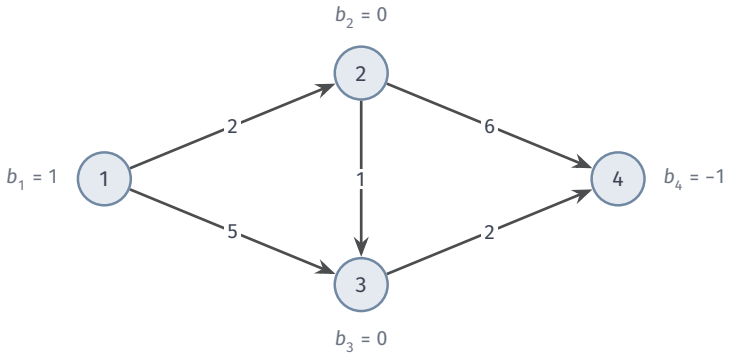


图 2.1　一个小网络流实例。弧旁的数字是单位费用 $c_{i,j}$，节点旁的 b_i 是净供给：正数表示运出，负数表示收到，零表示只中转。每条弧上的流量 $x_{i,j} \geq 0$ 待定。

记弧 (i, j) 上的流量为 $x_{i,j} \geq 0$。每个节点都要平账：运出的总量减去运入的总量，等于该节点的净供给 b_i，这称为流量守恒。把五条弧按

$(1,2),(1,3),(2,3),(2,4),(3,4)$ 排列，四个守恒等式合起来就是 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$，其中

$$\boldsymbol{A}=\begin{bmatrix} 1 & 1 & 0 & 0 & 0 \\ -1 & 0 & 1 & 1 & 0 \\ 0 & -1 & -1 & 0 & 1 \\ 0 & 0 & 0 & -1 & -1 \end{bmatrix},\qquad \boldsymbol{b}=\begin{bmatrix} 1 \\ 0 \\ 0 \\ -1 \end{bmatrix}. \tag{2.3}$$

$\boldsymbol{A}$ 的每一列对应一条弧，在弧的起点处为 $+1$，在终点处为 -1，其余为零，它是有向图的关联矩阵。

费用向量是 $\boldsymbol{c}=(2,5,1,6,2)^{\top}$，总费用 $\boldsymbol{c}^{\top}\boldsymbol{x}$ 是线性函数。于是最小费用的运送方案由下面的问题决定：

$$\min_{\boldsymbol{x}}\ \boldsymbol{c}^{\top}\boldsymbol{x}\quad \text{s.t.}\quad \boldsymbol{A}\boldsymbol{x}=\boldsymbol{b},\quad \boldsymbol{x}\geq \boldsymbol{0}.$$

这里净供给恰好是把一单位货物从节点 1 送到节点 4，所以问题就是求最短路。若某条弧还有容量上限 $x_{i,j}\leq u_{i,j}$，只需多加一条不等式。图上这些问题的专门算法可参考卷三第 7 章“最小费用流”，本章只把它们当作线性规划的实例。

标准型　比较两个模型：资源配置用“$\leq$”约束一般的线性组合，网络流用等式，只把不等号留给单个变量。第二种写法对计算更方便。一组等式可以用线性代数处理，而不等式全部成了“某个坐标非负”，这是最简单的一种不等式。我们把它定为统一的形式。

定义 2.2　线性规划的标准型　给定 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$、$\boldsymbol{b}\in\mathbb{R}^{m}$ 和 $\boldsymbol{c}\in\mathbb{R}^{n}$，问题

$$\min_{\boldsymbol{x}\in\mathbb{R}^{n}}\ \boldsymbol{c}^{\top}\boldsymbol{x}\quad \text{s.t.}\quad \boldsymbol{A}\boldsymbol{x}=\boldsymbol{b},\quad \boldsymbol{x}\geq \boldsymbol{0} \tag{2.4}$$

称为线性规划的**标准型**（standard form），它的可行集记为

$$\boldsymbol{C}=\{\boldsymbol{x}\in\mathbb{R}^{n}\ :\ \boldsymbol{A}\boldsymbol{x}=\boldsymbol{b},\ \boldsymbol{x}\geq\boldsymbol{0}\}. \tag{2.5}$$

$\boldsymbol{A}$ 的第 j 列记为 $\boldsymbol{a}_j=\boldsymbol{A}_{:,j}$，最优值记为 $p^{\star}$。

可以把标准型想成一本账：每个等式是一笔必须平的账，每个变量是一项不能为负的余额。这个比喻只说明约束的形式，并不表示变量都有“余额”的含义。

改写成标准型　一般的线性规划可以逐项改写。每一步都要说清新旧问题的解怎样相互对应，下面逐种列出。

最大化改为最小化。最大化 $\boldsymbol{p}^{\top}\boldsymbol{x}$ 与最小化 $(-\boldsymbol{p})^{\top}\boldsymbol{x}$ 的最优解相同，最优值互为相反数。

小于等于约束。对 $\boldsymbol{g}^{\top}\boldsymbol{x} \le h$，引入新变量 $s = h - \boldsymbol{g}^{\top}\boldsymbol{x}$，约束等价于

$$\boldsymbol{g}^{\top}\boldsymbol{x} + s = h, \qquad s \ge 0. \tag{2.6}$$

s 称为**松弛变量**（slack variable），它是这条约束还剩的余量。

大于等于约束。对 $\boldsymbol{g}^{\top}\boldsymbol{x} \ge h$，减去**剩余变量**（surplus variable）$s = \boldsymbol{g}^{\top}\boldsymbol{x} - h \ge 0$，得到 $\boldsymbol{g}^{\top}\boldsymbol{x} - s = h$。

变量有上下界。若 $x_j \ge l_j$，令 $x'_j = x_j - l_j \ge 0$；若 $x_j \le u_j$，把它当作一条“小于等于”约束加松弛变量。

无符号限制的变量。这样的变量称为**自由变量**（free variable）。把它写成两个非负变量之差：

$$x_j = x_j^{+} - x_j^{-}, \qquad x_j^{+} \ge 0, \quad x_j^{-} \ge 0. \tag{2.7}$$

示例 2.3　车间问题的标准型　为工时和原料分别引入松弛变量 $x_3, x_4 \ge 0$，把最大化利润改成最小化利润的相反数，就得到 $n = 4$，$m = 2$ 的标准型，数据是

$$\boldsymbol{A} = \begin{bmatrix} 1 & 1 & 1 & 0 \\ 2 & 1 & 0 & 1 \end{bmatrix}, \quad \boldsymbol{b} = \begin{bmatrix} 4 \\ 6 \end{bmatrix}, \quad \boldsymbol{c} = \begin{bmatrix} -3 \\ -2 \\ 0 \\ 0 \end{bmatrix}. \tag{2.8}$$

第 1章的解 $(x_1, x_2) = (2, 2)$ 对应 $\boldsymbol{x} = (2, 2, 0, 0)^{\top}$，工时和原料都恰好用完，目标值是 -10。

松弛变量的意义可以直接在图上读出。图 2.2中，取产量 $(1, 1)$，代入得到

$$x_3 = 4 - 1 - 1 = 2, \qquad x_4 = 6 - 2 - 1 = 3.$$

也就是工时还剩 2，原料还剩 3。$x_3 = 0$ 恰好是工时约束的边界，$x_3 = 2$ 是与边界平行的另一条直线。平面上每个点都对应一组松弛变量的值，点走到哪条边界上，对应的松弛变量就降为零。

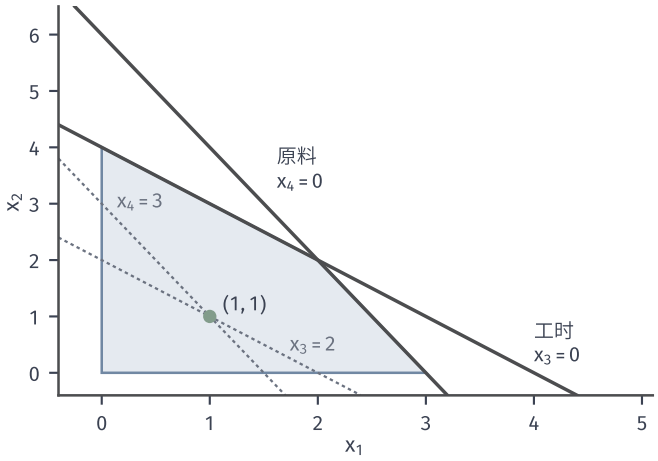


图 2.2 车间问题的松弛变量。深灰粗线是约束取等号的边界，也就是 $x_3 = 0$ 和 $x_4 = 0$。过绿点 $(1,1)$ 的两条灰色点线是与边界平行的直线，在它们上面 $x_3 = 2$，$x_4 = 3$，表示这一产量剩下的工时和原料。

改写保留了什么 松弛变量的引入是一一对应的。原问题的可行点 $\boldsymbol{x}$ 对应新问题的可行点 $(\boldsymbol{x}, \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x})$，反过来，丢掉松弛变量就回到原来的点。目标值不变，因为松弛变量的费用是零。这个对应是仿射映射，保持线段和中点，所以可行集的形状也保留下来：车间的四边形搬进了 $\mathbb{R}^4$，还是同一个四边形。

自由变量的分解不同。从分解后的可行点总能算出原来的 x_j，目标值相同，所以最优值和最优解的集合不变。但同一个 x_j 有无穷多种写法，图 2.3中 $(x^+, x^-) = (1,0)$ 和 $(3,2)$ 都表示 $x = 1$。

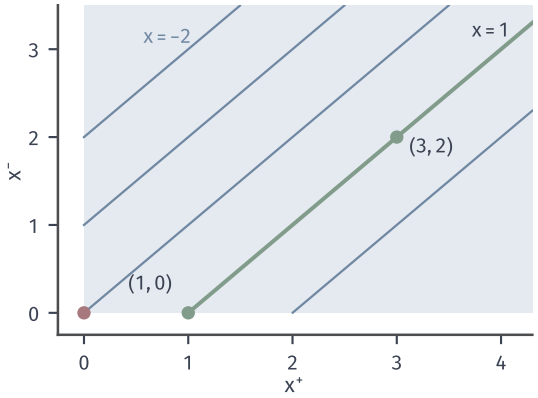


图 2.3 自由变量的分解 $x = x^+ - x^-$。浅蓝区域是分解后允许的第一象限，每条斜线上的点代表同一个 x，绿色粗线是 $x = 1$。原来的直线变成了一个象限，红点 $(0,0)$ 是这个象限唯一的角点，它在原来的直线上只是普通的一点 $x = 0$。

2.1 线性规划的表述
2.2 基本可行解
2.3 线性规划的对偶
2.4 线性松弛
2.5 本章小结

分解后新问题的最优解可能不唯一，例如沿斜线同时增大 x^+ 和 x^-，目标值不变。分解还会凭空造出角点：实数轴没有角，第一象限却有角点 $(0,0)$。下一节谈顶点时要记住这一点。表 2.1汇总了各种改写的效果。

改写	解的对应	变化
最大改最小	最优解相同	最优值变号
加松弛或剩余变量	一一对应	变量增加，形状不变
变量平移	一一对应	平移可行集
自由变量分解	多对一	可能多出角点和最优解

表 2.1　改写成标准型时各步保留的内容。每一步都保持最优值（或只差符号与常数），并且可以从新问题的解算出原问题的解。

冗余等式与满行秩　下一节要从 $\boldsymbol{A}$ 中选出可逆的方阵，这需要 $\boldsymbol{A}$ 的行没有多余。网络流的矩阵 (2.3)就有多余的行：每一列恰有一个 $+1$ 和一个 -1，所以四行相加是零向量，第四行是前三行之和的相反数。$\boldsymbol{b}$ 的分量相加也是零，这说明总供给等于总需求，等式组是相容的。

一般的处理分两步。先检查等式组是否相容，也就是比较 $\operatorname{rank}\boldsymbol{A}$ 和增广矩阵的秩：

$$\operatorname{rank}\boldsymbol{A} = \operatorname{rank}\begin{bmatrix}\boldsymbol{A} & \boldsymbol{b}\end{bmatrix}.$$

若上式不成立，等式组无解，可行集是空集，问题到此回答完毕。在网络中这对应总供给不等于总需求，货物无处可去。

若相容且 $\operatorname{rank}\boldsymbol{A} = r < m$，就选出 r 个线性无关的行，其余的行是它们的线性组合，右端也是相应的组合，删去后解集不变。网络的例子里删去第四行即可，剩下三行线性无关，这只要看弧 $(1,2),(2,3),(3,4)$ 三列组成的 3×3 子矩阵，它是可逆的三角矩阵。秩判别和选主元消元的做法可参考卷二第 11 章“线性方程与最小二乘的选解”。

以后凡涉及基矩阵，都假设已完成这一步，即

$$\operatorname{rank}\boldsymbol{A} = m \le n. \tag{2.9}$$

车间问题的 $\boldsymbol{A}$ 含有单位矩阵，自动满行秩。

2.2 基本可行解

线性规划的最优解是否一定落在角点上，角点又怎样用矩阵计算出来？车间问题里这一点靠眼睛看到，变量多了就要靠下面的定义和定理。

多面体与极点 车间的四边形由四个半平面相交而成。一般地，满足 $\boldsymbol{g} \neq \mathbf{0}$ 的集合 $\{\boldsymbol{x} : \boldsymbol{g}^{\top}\boldsymbol{x} \leq h\}$ 称为**半空间**（halfspace），有限个半空间的交称为**多面体**（polyhedron）。写成矩阵形式，就是

$$\boldsymbol{Q} = \{\boldsymbol{x} \in \mathbb{R}^n : \boldsymbol{G}\boldsymbol{x} \leq \boldsymbol{h}\}, \tag{2.10}$$

其中 $\boldsymbol{G}$ 的行数有限。等式可以写成两条方向相反的不等式，所以标准型的可行集 $\boldsymbol{C}$ 也是多面体。半空间是闭凸集，有限个闭凸集的交仍是闭凸集，多面体因此是闭凸集。

“角点”需要一个不依赖图形的说法。观察图 2.4：内部的点是某条可行线段的中点，边上的点也是，只不过线段只能沿边摆放。顶点不同，过它的线段无论怎么摆，总有一端跑到可行集外面。

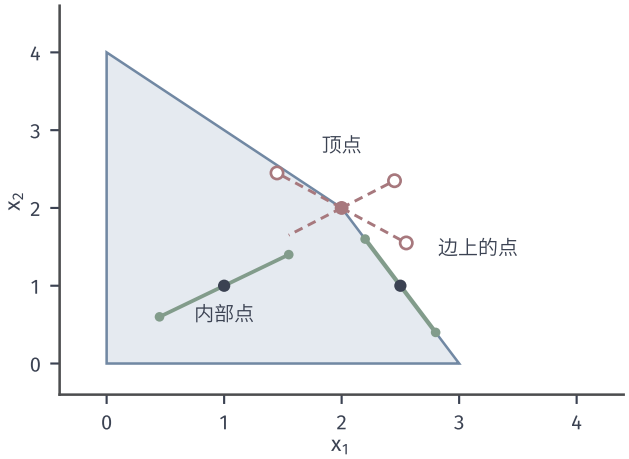


图 2.4 三种位置的点。深色的内部点和边上的点都是一条可行线段（绿色）的中点。红点 $(2, 2)$ 是顶点，过它的线段（红色虚线）总有一端落在四边形外（空心点），所以它不是任何可行线段的中点。

> **定义 2.4 极点** 设 $\boldsymbol{Q}$ 是凸集，$\boldsymbol{x} \in \boldsymbol{Q}$。若 $\boldsymbol{u}, \boldsymbol{v} \in \boldsymbol{Q}$ 且 $\boldsymbol{x} = (\boldsymbol{u} + \boldsymbol{v})/2$ 只有在 $\boldsymbol{u} = \boldsymbol{v} = \boldsymbol{x}$ 时才成立，就称 $\boldsymbol{x}$ 是 $\boldsymbol{Q}$ 的**极点**（extreme point）。

对多面体，极点也称为顶点，本章两种说法通用。

基与基本解 标准型的可行点要满足 m 个等式，却有 n 个未知数，还剩 $n - m$ 个自由度。平面上的顶点是让两条约束同时取等号得到的，在标准型里，取等号的办法是让坐标变成零。于是自然的做法是：让 $n - m$ 个坐标取零，用 m 个等式解出其余 m 个坐标。

能否解出，取决于留下的那 m 列是否线性无关。

定义 2.5 基与基本可行解 设 $\boldsymbol{A}$ 满行秩。取 m 个下标组成集合 B，其余下标组成 N。若由 B 中各列构成的方阵 $\boldsymbol{A}_B$ 可逆，就称 B 为一个基，$\boldsymbol{A}_B$ 为**基矩阵**（basis matrix）。令

$$\boldsymbol{x}_B = \boldsymbol{A}_B^{-1}\boldsymbol{b}, \qquad \boldsymbol{x}_N = \boldsymbol{0}, \tag{2.11}$$

所得的 $\boldsymbol{x}$ 称为基 B 对应的**基本解**（basic solution），$\boldsymbol{x}_B$ 和 $\boldsymbol{x}_N$ 的分量分别称为基分量和非基分量。若还有 $\boldsymbol{x}_B \geq \boldsymbol{0}$，就称 $\boldsymbol{x}$ 为**基本可行解**（basic feasible solution），B 为可行基。

基本解满足全部等式，但不一定非负，所以不一定可行。在车间问题 (2.8)中，$\boldsymbol{A}$ 的四列任取两列都线性无关，共有 $\binom{4}{2} = 6$ 个基。以 $B = \{1, 4\}$ 为例，令 $x_2 = x_3 = 0$，两个等式变成

$$x_1 = 4, \qquad 2x_1 + x_4 = 6.$$

解得 $x_1 = 4$，$x_4 = -2$。分量为负，这个基本解不可行：产量 $(4, 0)$ 用掉的原料比库存多 2。表 2.2列出了全部六个基本解。

基 B	$\boldsymbol{x} = (x_1, x_2, x_3, x_4)$	平面上的点	是否可行
$\{3, 4\}$	$(0, 0, 4, 6)$	$(0, 0)$	可行
$\{1, 3\}$	$(3, 0, 1, 0)$	$(3, 0)$	可行
$\{2, 4\}$	$(0, 4, 0, 2)$	$(0, 4)$	可行
$\{1, 2\}$	$(2, 2, 0, 0)$	$(2, 2)$	可行
$\{1, 4\}$	$(4, 0, 0, -2)$	$(4, 0)$	不可行
$\{2, 3\}$	$(0, 6, -2, 0)$	$(0, 6)$	不可行

表 2.2 车间问题的六个基本解。可行的四个恰好是四边形的四个顶点。

图 2.5把这六个点画在平面上。它们正是四条边界直线的两两交点：选定基，就是选定哪两个坐标取零，也就是选定哪两条边界同时取等号。

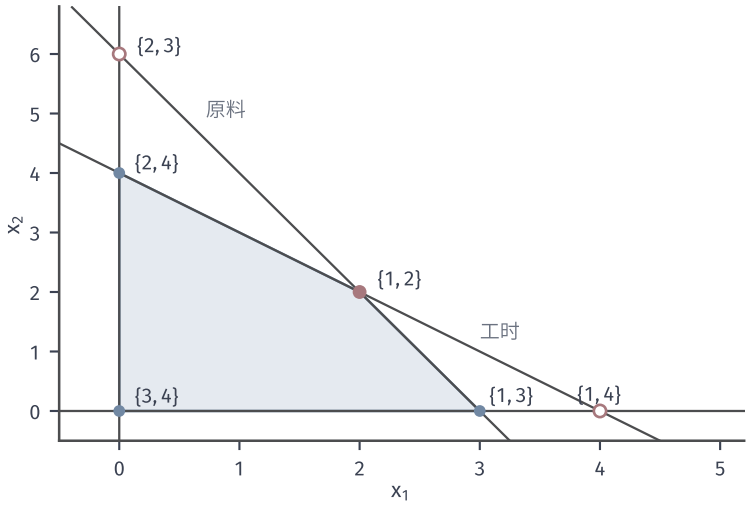


图 2.5 车间问题的六个基本解，点旁标出对应的基。四条直线是 $x_1 = 0$、$x_2 = 0$ 和工时、原料两条约束的边界。实心点是四个基本可行解，其中红点 $(2, 2)$ 最优；红色空心点 $(4, 0)$ 和 $(0, 6)$ 的基本解有负分量，落在可行域外。

基本可行解就是极点 表中四个可行的基本解恰好是四个顶点，这不是巧合。下面的定理把代数对象和几何对象连起来，判别的依据是矩阵的秩：只看正分量所在的列。

定理 2.6 基本可行解与极点 设 $\boldsymbol{A}$ 满行秩，$\boldsymbol{x} \in \boldsymbol{C}$，$J = \{j : x_j > 0\}$。下面三条等价：

1. $\boldsymbol{x}$ 是 $\boldsymbol{C}$ 的极点；
2. 列 $\{\boldsymbol{a}_j : j \in J\}$ 线性无关；
3. $\boldsymbol{x}$ 是某个基对应的基本可行解。

证明 先证 (1) 推出 (2)。假设这些列线性相关，则有不全为零的系数 w_j（$j \in J$）使 $\sum_{j \in J} w_j \boldsymbol{a}_j = \boldsymbol{0}$。把 $\boldsymbol{w}$ 在 J 以外的分量补成零，就有

$$\boldsymbol{A}\boldsymbol{w} = \boldsymbol{0}, \qquad \boldsymbol{w} \neq \boldsymbol{0}.$$

J 上的 x_j 都是正数，取足够小的 $\varepsilon > 0$，可使 $\boldsymbol{x} \pm \varepsilon \boldsymbol{w} \geq \boldsymbol{0}$。再由 $\boldsymbol{A}\boldsymbol{w} = \boldsymbol{0}$ 知这两个点都满足等式，都可行。它们不相等，而 $\boldsymbol{x}$ 是它们的中点，与 $\boldsymbol{x}$ 是极点矛盾。

再证 (2) 推出 (3)。线性无关的列不超过 m 个，所以 $|J| \leq m$。$\boldsymbol{A}$ 满行秩，它的列张成 $\mathbb{R}^m$，可以再补入若干列，把 $\{\boldsymbol{a}_j : j \in J\}$ 扩充成

$\mathbb{R}^m$ 的一组基，相应的下标集记为 $B \supseteq J$。于是 $\boldsymbol{A}_B$ 可逆，B 之外的分量都不在 J 中，所以 $\boldsymbol{x}_N = \boldsymbol{0}$。代入等式得到

$$\boldsymbol{A}_B \boldsymbol{x}_B = \boldsymbol{b}, \qquad \text{即} \qquad \boldsymbol{x}_B = \boldsymbol{A}_B^{-1} \boldsymbol{b}.$$

又 $\boldsymbol{x}$ 可行，故 $\boldsymbol{x}_B \geq \boldsymbol{0}$，它是基 B 的基本可行解。

最后证 (3) 推出 (1)。设 $\boldsymbol{x}$ 是基 B 的基本可行解，且 $\boldsymbol{x} = (\boldsymbol{u} + \boldsymbol{v})/2$，$\boldsymbol{u}, \boldsymbol{v} \in \boldsymbol{C}$。对 $j \in N$，有 $u_j + v_j = 2x_j = 0$，又 $u_j, v_j \geq 0$，所以 $u_j = v_j = 0$。于是 $\boldsymbol{A}_B \boldsymbol{u}_B = \boldsymbol{b}$，由 $\boldsymbol{A}_B$ 可逆得到

$$\boldsymbol{u}_B = \boldsymbol{A}_B^{-1} \boldsymbol{b} = \boldsymbol{x}_B.$$

所以 $\boldsymbol{u} = \boldsymbol{x}$，同理 $\boldsymbol{v} = \boldsymbol{x}$。 ■

定理中的秩条件有直接的几何解释。在点 $\boldsymbol{x}$ 处取等号的约束是 m 个等式和 $n - |J|$ 个“坐标为零”。把它们的系数排成矩阵 $\boldsymbol{M}$，$\boldsymbol{M}\boldsymbol{v} = \boldsymbol{0}$ 说的是

$$\boldsymbol{v}_{J^c} = \boldsymbol{0}, \qquad \boldsymbol{A}_J \boldsymbol{v}_J = \boldsymbol{0}.$$

其中 J^c 是 J 的补集。所以 $\boldsymbol{M}$ 的列满秩，也就是取等号的约束能唯一确定一个点，当且仅当 $\boldsymbol{A}_J$ 的列线性无关。“n 个线性无关的约束取等号”和“基矩阵可逆”是同一件事的两种说法。

用车间问题验证一下。点 $(5/2, 1)$ 对应 $\boldsymbol{x} = (5/2, 1, 1/2, 0)^\top$，正分量在第 $1, 2, 3$ 列，三列放在 $\mathbb{R}^2$ 中线性相关，取

$$\boldsymbol{w} = (-1, 2, -1, 0)^\top, \qquad \boldsymbol{A}\boldsymbol{w} = \boldsymbol{0}.$$

$\boldsymbol{x} \pm \varepsilon \boldsymbol{w}$ 都可行，所以它不是极点，在图上它是原料边界中间的一点。点 $(2, 2)$ 对应 $\boldsymbol{x} = (2, 2, 0, 0)^\top$，第 $1, 2$ 列线性无关，它是极点。

基的个数不超过 $\binom{n}{m}$，所以极点只有有限个。最优解若能在极点取得，问题就从无穷多个候选变成了有限多个。

最优解可以在基本可行解中取得 下面证明这确实成立。证明的想法很具体：任取一个可行点，如果它的正分量对应的列线性相关，就有一个方向可以沿着走，目标不变差，直到某个正分量降到零。正分量越来越少，最后得到一个基本可行解。

引理 2.7　推向基本可行解　设 $\boldsymbol{A}$ 满行秩，且 $\boldsymbol{c}^{\top}\boldsymbol{x}$ 在 $\boldsymbol{C}$ 上有下界。则对每个 $\boldsymbol{x}\in\boldsymbol{C}$，存在基本可行解 $\hat{\boldsymbol{x}}$，使

$$\boldsymbol{c}^{\top}\hat{\boldsymbol{x}}\le\boldsymbol{c}^{\top}\boldsymbol{x}. \tag{2.12}$$

证明　对正分量的个数 $|J|$ 归纳。若列 $\{\boldsymbol{a}_j : j\in J\}$ 线性无关，由定理 2.6，$\boldsymbol{x}$ 本身就是基本可行解。

否则取 $\boldsymbol{w}\neq\boldsymbol{0}$，满足 $\boldsymbol{A}\boldsymbol{w}=\boldsymbol{0}$，且 $w_j=0$ 对 $j\notin J$ 成立。必要时用 $-\boldsymbol{w}$ 代替 $\boldsymbol{w}$，可使 $\boldsymbol{c}^{\top}\boldsymbol{w}\le 0$。先说明可以假设 $\boldsymbol{w}$ 有负分量。

若 $\boldsymbol{w}\ge\boldsymbol{0}$ 且 $\boldsymbol{c}^{\top}\boldsymbol{w}<0$，则对一切 $t\ge 0$，点 $\boldsymbol{x}+t\boldsymbol{w}$ 可行，目标值 $\boldsymbol{c}^{\top}\boldsymbol{x}+t\boldsymbol{c}^{\top}\boldsymbol{w}$ 趋于 $-\infty$，与有下界矛盾，这种情形不出现。若 $\boldsymbol{w}\ge\boldsymbol{0}$ 且 $\boldsymbol{c}^{\top}\boldsymbol{w}=0$，就把 $\boldsymbol{w}$ 换成 $-\boldsymbol{w}$，此时 $\boldsymbol{c}^{\top}\boldsymbol{w}$ 仍为零，而 $\boldsymbol{w}$ 有了负分量。

现在令

$$t^{\star}=\min_{j:\,w_j<0}\frac{x_j}{-w_j},\qquad \boldsymbol{x}'=\boldsymbol{x}+t^{\star}\boldsymbol{w}.$$

负分量只出现在 J 中，那里 $x_j>0$，所以 $t^{\star}>0$。$t^{\star}$ 的取法保证 $\boldsymbol{x}'\ge\boldsymbol{0}$，又 $\boldsymbol{A}\boldsymbol{x}'=\boldsymbol{b}$，所以 $\boldsymbol{x}'$ 可行，并且

$$\boldsymbol{c}^{\top}\boldsymbol{x}'=\boldsymbol{c}^{\top}\boldsymbol{x}+t^{\star}\boldsymbol{c}^{\top}\boldsymbol{w}\le\boldsymbol{c}^{\top}\boldsymbol{x}.$$

J 之外的分量保持为零，取到最小值的分量变成零，所以 $\boldsymbol{x}'$ 的正分量个数严格减少。对 $\boldsymbol{x}'$ 用归纳假设，即得 $\hat{\boldsymbol{x}}$。 ∎

用车间问题走一遍。从可行点 $(x_1,x_2)=(1,1)$ 出发，四个坐标是 $\boldsymbol{x}=(1,1,2,3)^{\top}$，目标值 -5。四列放在 $\mathbb{R}^2$ 中必然线性相关，可以取下面的方向，并算出步长：

$$\boldsymbol{w}=(1,0,-1,-2)^{\top},\qquad \boldsymbol{c}^{\top}\boldsymbol{w}=-3,\qquad t^{\star}=\min\Big\{\frac{2}{1},\frac{3}{2}\Big\}=\frac{3}{2}.$$

走完得到第一个新点，x_4 降到了零：

$$\boldsymbol{x}'=\Big(\frac{5}{2},1,\frac{1}{2},0\Big)^{\top},\qquad \boldsymbol{c}^{\top}\boldsymbol{x}'=-\frac{19}{2}.$$

此时还剩三个正分量，第 $1,2,3$ 列在 $\mathbb{R}^2$ 中仍然线性相关。满足 $w_4=0$ 的零空间方向是 $(1,-2,1,0)^{\top}$，它的目标变化率是 $+1$，所以取反方向，并求步长：

$$\boldsymbol{w}=(-1,2,-1,0)^{\top},\qquad \boldsymbol{c}^{\top}\boldsymbol{w}=-1,\qquad t^{\star}=\min\Big\{\frac{5/2}{1},\frac{1/2}{1}\Big\}=\frac{1}{2}.$$

走完得到

$$\boldsymbol{x}'' = (2,2,0,0)^{\top}, \qquad \boldsymbol{c}^{\top}\boldsymbol{x}'' = -10.$$

正分量只剩两个，对应的列线性无关，这就是基本可行解。图 2.6显示了这两步：先水平走到原料边界，再沿边界走到顶点。这里碰巧到达了最优解，一般只能保证目标不变差。

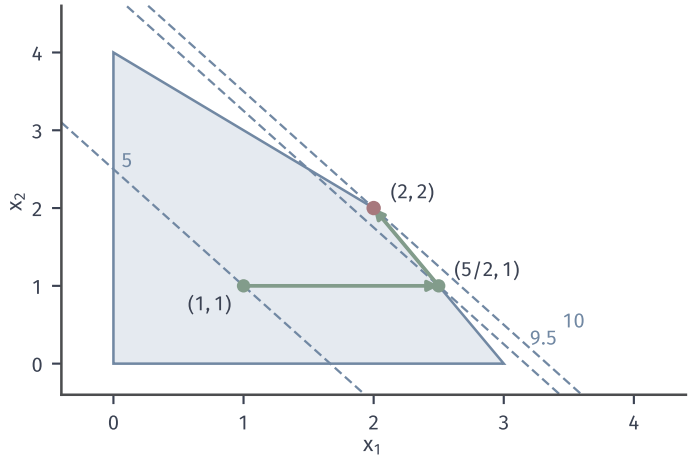


图 2.6 引理 2.7在车间问题上的两步。绿色箭头从 $(1,1)$（四个正分量）走到 $(5/2,1)$（三个正分量），再走到顶点 $(2,2)$（两个正分量）。蓝色虚线是利润等于 5、9.5、10 的等值线，每一步都不使利润变小。

定理 2.8 最优基本可行解的存在 设 $\boldsymbol{A}$ 满行秩。若标准型 (2.4)可行且最优值有限，则最优值能够取到，并且至少有一个最优解是基本可行解。特别地，非空的 $\boldsymbol{C}$ 至少有一个极点。

证明 基本可行解至多有 $\binom{n}{m}$ 个，由引理 2.7（对 $\boldsymbol{C}$ 中任一点使用），它们至少有一个。在这有限个点中取目标值最小的 $\boldsymbol{x}^{\star}$。对任意 $\boldsymbol{x} \in \boldsymbol{C}$，引理给出基本可行解 $\hat{\boldsymbol{x}}$，于是

$$\boldsymbol{c}^{\top}\boldsymbol{x} \geq \boldsymbol{c}^{\top}\hat{\boldsymbol{x}} \geq \boldsymbol{c}^{\top}\boldsymbol{x}^{\star}.$$

所以 $\boldsymbol{x}^{\star}$ 是最优解。最后一句取 $\boldsymbol{c} = \boldsymbol{0}$ 即得。 ■

定理中“$\boldsymbol{A}$ 满行秩”只是为了让基有定义，这一点上一节已经保证。这个结论比一般的存在定理强。第 1章的 e^{x} 有下界却取不到下确界，而标准型线性规划只要最优值有限，就一定取得到，并不要求可行集有界。条件里的“可行”和“最优值有限”各自排除一种结局，图 2.7画出了线性规划的三种情形。

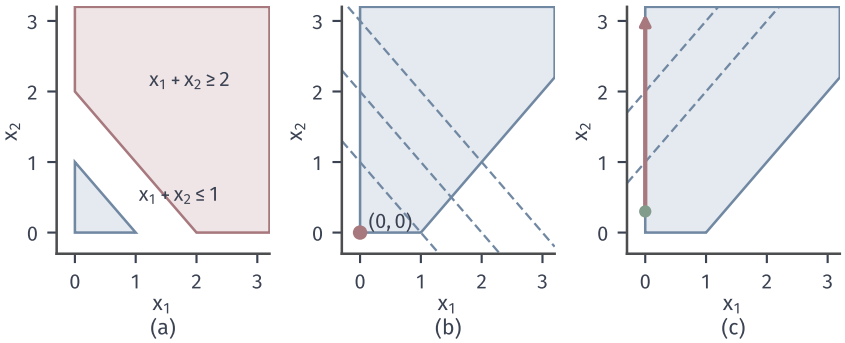


图 2.7 线性规划的三种结局。(a) 第一象限中两条约束围成的区域不相交，问题不可行。(b) 可行域 $\{\boldsymbol{x} \geq \mathbf{0},\ x_1 - x_2 \leq 1\}$ 无界，但最小化 $x_1 + x_2$（蓝色虚线是等值线）的最优解存在，是红点 $(0,0)$。(c) 同一可行域上最小化 $x_1 - x_2$，从绿点沿红色射线一直走，目标趋于 $-\infty$，问题无下界。

定理只说有一个最优解是基本可行解，不说所有最优解都是。把车间的目标改成最大化 $2x_1 + x_2$，等值线与原料边界平行，图 2.8(b) 中 $(2,2)$ 和 $(3,0)$ 都最优，它们连线上的每一点也都最优。中点 $(5/2,1)$ 对应 $\boldsymbol{x} = (5/2, 1, 1/2, 0)^{\mathsf{T}}$，有三个正分量，多于 $m = 2$，所以不是基本可行解，却同样最优。

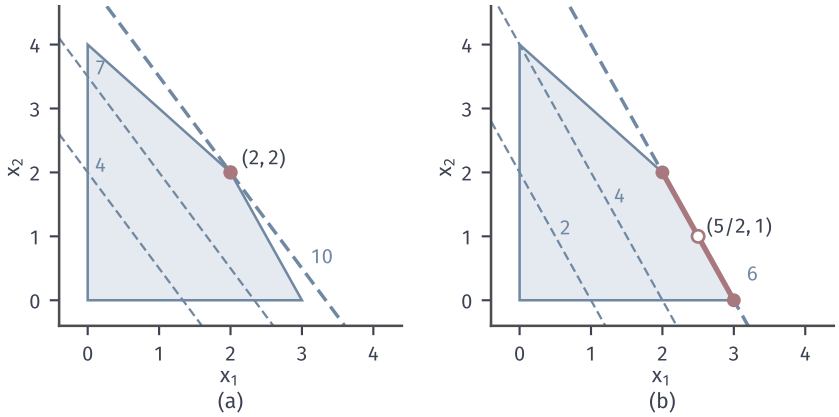


图 2.8 等值线平移到最后接触可行域的情形。(a) 最大化 $3x_1 + 2x_2$，粗虚线（利润 10）只接触顶点 $(2,2)$，最优解唯一。(b) 最大化 $2x_1 + x_2$，粗虚线（值为 6）与一条边重合，红色线段上都是最优解，其中空心点 $(5/2,1)$ 不是顶点。

定理把问题化成了有限比较，但枚举全部的基并不现实。$n = 100, m = 50$ 时，$\binom{n}{m}$ 约为 1.0×10^{29}。需要的是一种不逐个检查、只在相邻顶点之间移动的办法，下面先说清“相邻”是什么意思。

沿边到相邻顶点 在车间的四边形上，相邻顶点由一条边相连。用基来说，相邻的两个基只差一个下标。设 B 是可行基，$\bar{\boldsymbol{x}}$ 是它的基本可行解，取一

个不在 B 中的下标 q。让 x_q 从零增大，其余非基分量保持为零，基分量必须随之调整，以维持等式。由 $\boldsymbol{A}_B\boldsymbol{x}_B + \boldsymbol{a}_q x_q = \boldsymbol{b}$ 解出

$$\boldsymbol{x}_B = \bar{\boldsymbol{x}}_B - x_q \boldsymbol{u}, \qquad \boldsymbol{u} = \boldsymbol{A}_B^{-1}\boldsymbol{a}_q. \tag{2.13}$$

这相当于让点沿方向 $\boldsymbol{d}$ 移动，其中 $d_q = 1$，$\boldsymbol{d}_B = -\boldsymbol{u}$，其余分量为零，并且 $\boldsymbol{A}\boldsymbol{d} = \boldsymbol{0}$。

定理 2.9　沿边的移动　设 $\boldsymbol{A}$ 满行秩，B 是可行基，$\bar{\boldsymbol{x}}$ 是其基本可行解，$q \notin B$，$\boldsymbol{u}$ 和 $\boldsymbol{d}$ 如上。则满足“$x_j = 0$ 对 $j \notin B \cup \{q\}$ 成立”的可行点恰好是 $\bar{\boldsymbol{x}} + \alpha \boldsymbol{d}$，其中 $\alpha \geq 0$ 且 $\bar{\boldsymbol{x}}_B - \alpha \boldsymbol{u} \geq \boldsymbol{0}$。进一步：

1. 若 $\boldsymbol{u}$ 有正分量，且 $\bar{\boldsymbol{x}}_B > \boldsymbol{0}$，记 r 是下式取到最小值的位置，$B(i)$ 是基中第 i 个下标：

$$\alpha^\star = \min_{i:\, u_i > 0} \frac{\bar{x}_{B(i)}}{u_i} > 0. \tag{2.14}$$

   把 B 中的 $B(r)$ 换成 q 得到新基，$\bar{\boldsymbol{x}} + \alpha^\star \boldsymbol{d}$ 是新基的基本可行解，且与 $\bar{\boldsymbol{x}}$ 不同。

2. 若 $\boldsymbol{u} \leq \boldsymbol{0}$，则对一切 $\alpha \geq 0$，$\bar{\boldsymbol{x}} + \alpha \boldsymbol{d}$ 都可行。

证明　由式 (2.13)，满足等式且 $x_j = 0$（$j \notin B \cup \{q\}$）的点完全由 x_q 确定，就是 $\bar{\boldsymbol{x}} + x_q \boldsymbol{d}$。再加上非负条件，得到第一句。

对情形 1，$\bar{\boldsymbol{x}}_B > \boldsymbol{0}$ 保证 $\alpha^\star > 0$，点因此确实移动了。$\alpha^\star$ 的取法使基分量保持非负，而位置 r 上的分量降为零。新基矩阵可逆：由 $\boldsymbol{A}_B\boldsymbol{u} = \boldsymbol{a}_q$，有 $\boldsymbol{a}_q = \sum_i u_i \boldsymbol{a}_{B(i)}$，其中 $\boldsymbol{a}_{B(r)}$ 的系数 $u_r \neq 0$，所以用 $\boldsymbol{a}_q$ 替换 $\boldsymbol{a}_{B(r)}$ 后列仍线性无关。新点在新基之外的分量都是零，它就是新基的基本可行解。

对情形 2，$\boldsymbol{u} \leq \boldsymbol{0}$ 时基分量不减，$\alpha \geq 0$ 都满足非负条件。 ■

定理的第一句就是“边”的代数含义：m 个等式和 $n - m - 1$ 个坐标为零，共 $n - 1$ 个线性无关的条件，只留下一个自由度，可行点构成一条线段或射线。把一个下标换入、另一个换出，这个操作称为换基，它的几何含义在基分量都为正时正是沿边走到相邻顶点。选哪个 q 能改善目标，是第 3章的问题，这里只看移动本身。

在车间问题上从 $B = \{3, 4\}$，即点 $(0, 0)$ 出发，让 x_1 增大。此时 $\boldsymbol{A}_B = \boldsymbol{I}$，于是

$$\boldsymbol{u} = \boldsymbol{a}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \qquad \bar{\boldsymbol{x}}_B = \begin{bmatrix} 4 \\ 6 \end{bmatrix}, \qquad \alpha^\star = \min\left\{\frac{4}{1}, \frac{6}{2}\right\} = 3.$$

最小值由原料的松弛变量 x_4 取到，所以 x_4 换出，点沿下边走到 $(3,0)$，新基是 $\{1,3\}$，其中基分量 $x_1 = 3$，$x_3 = 4 - 3 = 1$。

再让 x_2 增大。新基矩阵的列是 $\boldsymbol{a}_1, \boldsymbol{a}_3$，解 $\boldsymbol{A}_B \boldsymbol{u} = \boldsymbol{a}_2$，并按位置比较：

$$\boldsymbol{u} = \begin{bmatrix} 1/2 \\ 1/2 \end{bmatrix}, \qquad \bar{\boldsymbol{x}}_B = \begin{bmatrix} 3 \\ 1 \end{bmatrix}, \qquad \alpha^\star = \min\left\{\frac{3}{1/2}, \frac{1}{1/2}\right\} = 2.$$

x_3 先降到零，x_1 变成 $3 - 2 \cdot \frac{1}{2} = 2$，$x_2$ 变成 2，点走到 $(2,2)$，基变成 $\{1,2\}$。图 2.9显示了这两次移动和第一次移动中基分量的变化。基 $\{3,4\}$ 和 $\{1,2\}$ 差两个下标，它们的顶点 $(0,0)$ 与 $(2,2)$ 不相邻，连接它们的线段穿过四边形内部，不是边。

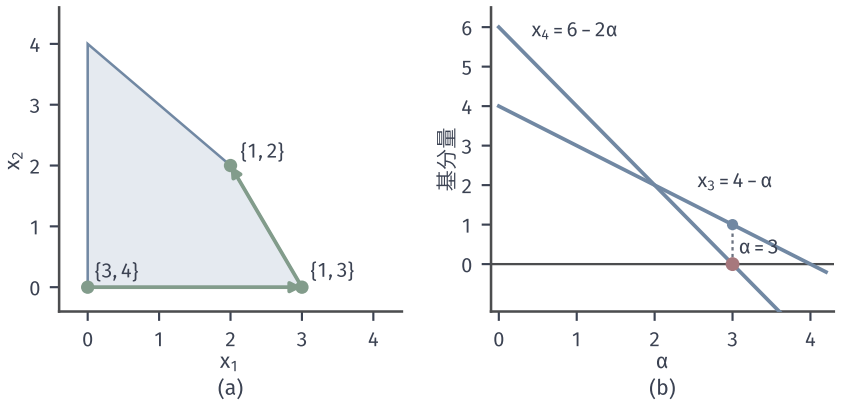


图 2.9 两次换基。(a) 绿色箭头沿边从 $(0,0)$ 到 $(3,0)$，再到 $(2,2)$，点旁是当时的基。(b) 第一次移动时两个基分量随步长 α 下降，x_4 在 $\alpha = 3$ 处最先到零（红点），此时 $x_3 = 1$。

含直线的多面体没有极点 以上结论都是对标准型说的。它们能推广到什么范围？在平面上考虑带形

$$\{(x_1, x_2) : 0 \le x_2 \le 1\}.$$

最小化 x_2，最优值 0 在整条直线 $x_2 = 0$ 上取得，但这个集合没有角点。图 2.10(a) 中，每个点都是左右两个可行点的中点。可见“有最优解就有最优顶点”不是所有多面体都有的性质，缺的是下面的秩条件。

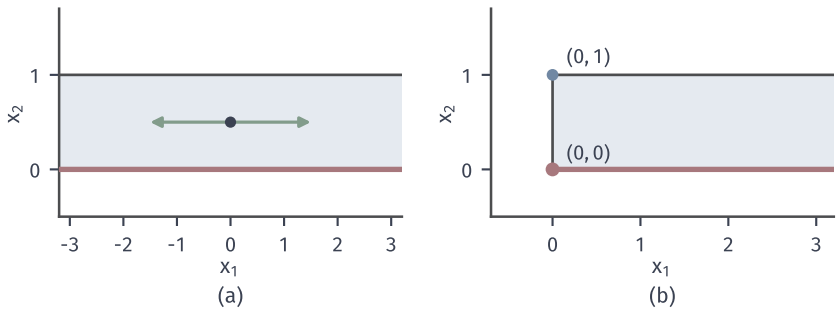


图 2.10 极点的存在依赖可行集的形状，目标取 x_2，红色粗线是最优解集合。(a) 带形含有水平直线，绿色线段说明任一点都是两个可行点的中点，所以没有极点，最优解集合也没有端点。(b) 加上 $x_1 \ge 0$ 后不再含直线，出现顶点 $(0,0)$ 和 $(0,1)$，最优值在顶点 $(0,0)$ 取得。

引理 2.10 多面体的极点 设 $Q = \{\boldsymbol{x} : \boldsymbol{G}\boldsymbol{x} \le \boldsymbol{h}\}$ 非空，其中 $\boldsymbol{G}$ 有 n 列。对 $\boldsymbol{x} \in Q$，记 $I(\boldsymbol{x})$ 为取等号的行的下标集。则 $\boldsymbol{x}$ 是极点，当且仅当 $\boldsymbol{G}_{I(\boldsymbol{x}),:}$ 的秩为 n。进一步，下面三条等价：Q 有极点；$\operatorname{rank}\boldsymbol{G} = n$；$Q$ 不含直线。

证明 先证第一句。若取等号的行的秩小于 n，存在 $\boldsymbol{d} \neq \boldsymbol{0}$ 使这些行与 $\boldsymbol{d}$ 的内积都为零。其余的行留有余量，$\varepsilon > 0$ 足够小时 $\boldsymbol{x} \pm \varepsilon\boldsymbol{d} \in Q$，所以 $\boldsymbol{x}$ 不是极点。反之设秩为 n，且 $\boldsymbol{x} = (\boldsymbol{u}+\boldsymbol{v})/2$，$\boldsymbol{u}, \boldsymbol{v} \in Q$。对每个 $i \in I(\boldsymbol{x})$，两个不超过 h_i 的数平均后等于 h_i，只能都等于 h_i，所以 $\boldsymbol{u}$ 和 $\boldsymbol{v}$ 满足相同的取等号方程组。这个方程组的解唯一，故 $\boldsymbol{u} = \boldsymbol{v} = \boldsymbol{x}$。

再证三条等价。若 $\operatorname{rank}\boldsymbol{G} < n$，取 $\boldsymbol{d} \neq \boldsymbol{0}$ 使 $\boldsymbol{G}\boldsymbol{d} = \boldsymbol{0}$，则过任一点沿 $\boldsymbol{d}$ 的直线都在 Q 中，这时由第一句也没有极点。反之若 Q 含直线 $\boldsymbol{x} + t\boldsymbol{d}$，则对全部 $t \in \mathbb{R}$ 有 $\boldsymbol{G}(\boldsymbol{x} + t\boldsymbol{d}) \le \boldsymbol{h}$，只能 $\boldsymbol{G}\boldsymbol{d} = \boldsymbol{0}$，秩小于 n。若有极点，由第一句 $\boldsymbol{G}$ 的秩为 n。

剩下要证 $\operatorname{rank}\boldsymbol{G} = n$ 时有极点。取 Q 中使 $\operatorname{rank}\boldsymbol{G}_{I(\boldsymbol{x}),:}$ 最大的点 $\boldsymbol{x}$。假设这个秩小于 n，取 $\boldsymbol{d} \neq \boldsymbol{0}$ 与取等号的行都正交。由 $\operatorname{rank}\boldsymbol{G} = n$，$\boldsymbol{G}\boldsymbol{d} \neq \boldsymbol{0}$，必要时换成 $-\boldsymbol{d}$，可设有一行的内积为正。沿 $\boldsymbol{d}$ 走到第一条新约束取等号为止，原来取等号的行仍取等号，新行与 $\boldsymbol{d}$ 不正交，不在原来那些行的张成中，秩增大，矛盾。所以这个秩等于 n，$\boldsymbol{x}$ 是极点。 ■

标准型中 $\boldsymbol{G}$ 含有 $-\boldsymbol{I}$ 这一块，秩一定是 n，所以非负约束自动排除了直线。定理 2.8成立的前提正是这一点。

上一节说自由变量分解会造出角点，这里可以看得很清楚。把带形写成标准型：令 $x_1 = x_1^+ - x_1^-$，加松弛变量 w，约束只剩一个等式 $x_2 + w = 1$。

基只能是 $\{x_2\}$ 或 $\{w\}$，基 $\{w\}$ 给出的基本可行解 $(x_1^+, x_1^-, x_2, w) = (0,0,0,1)$ 是最优的。它对应带形中的点 $(0,0)$，这个点是最优解，却不是带形的顶点。所以应用定理时要分清：顶点是标准型的顶点，回到原问题后只保证是一个最优解。

退化基与无界可行方向 基和点的对应还有两种偏差，表现相似，含义却不同，都发生在换基的时候。

第一种是几个基对应同一个点。给车间问题再加一条约束 $x_1 \le 3$，引入松弛变量 x_5，得到 $m=3$，$n=5$ 的标准型。可行域没有变化，但顶点 $(3,0)$ 现在有三条边界经过，如图 2.11。这个点是

$$\boldsymbol{x} = (3,0,1,0,0)^{\mathsf{T}},$$

只有 x_1, x_3 两个正分量，而基需要三个下标。

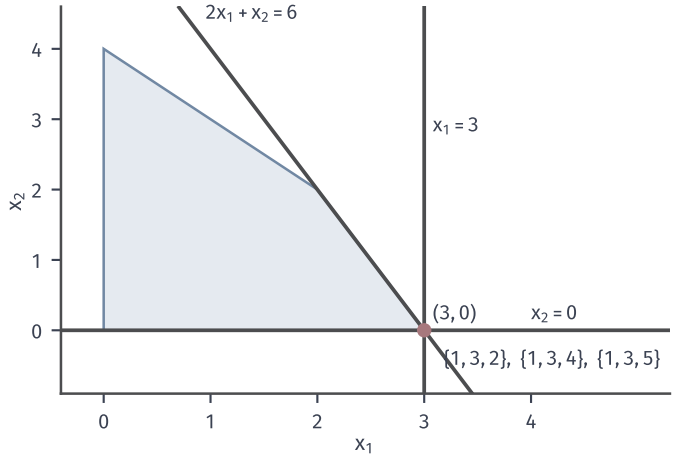


图 2.11 退化顶点。加入约束 $x_1 \le 3$ 后，四边形没有变，但三条深灰粗线同时经过红点 $(3,0)$。第三个基下标取 2、4 或 5，三个基 $\{1,3,2\}$、$\{1,3,4\}$、$\{1,3,5\}$ 都给出这同一个点。

第三个下标可以取 2、4 或 5，三个基矩阵都可逆，所以三个基给出同一个点，每个基中都有一个取零的基分量。这样的基称为**退化基**（degenerate basis），对应的基本可行解称为退化的。此时定理 2.9的条件 $\bar{\boldsymbol{x}}_B > \boldsymbol{0}$ 不成立。

从基 $\{1,3,2\}$（基分量依次为 $3,1,0$）出发，让 x_4 增大，解 $\boldsymbol{A}_B\boldsymbol{u} = \boldsymbol{a}_4$ 得到

$$\boldsymbol{u} = (0,-1,1)^{\mathsf{T}}, \qquad \alpha^\star = \frac{0}{1} = 0.$$

基变成 $\{1,3,4\}$，点却一动不动。“换基”和“走到另一个顶点”在退化时不再是一回事。

2.1 线性规划的表述
2.2 基本可行解
2.3 线性规划的对偶
2.4 线性松弛
2.5 本章小结

第二种是沿某条边可以走到无穷远。取可行域 $x_1 - x_2 \le 1$，$\boldsymbol{x} \ge \mathbf{0}$，写成标准型 $x_1 - x_2 + x_3 = 1$，这里 $m = 1$。在基 $\{3\}$ 处，点是 $(0,0,1)^{\mathsf{T}}$。让 x_2 增大：

$$u = \boldsymbol{A}_B^{-1}\boldsymbol{a}_2 = -1 \le 0.$$

由定理 2.9的情形 2，沿 $\boldsymbol{d} = (0,1,1)^{\mathsf{T}}$ 可以一直走。满足下面条件的 $\boldsymbol{d}$ 称为**无界可行方向**（unbounded feasible direction）：

$$\boldsymbol{A}\boldsymbol{d} = \mathbf{0}, \qquad \boldsymbol{d} \ge \mathbf{0}, \qquad \boldsymbol{d} \ne \mathbf{0}. \tag{2.15}$$

任何可行点沿它走都不会离开 $\boldsymbol{C}$。这是可行集形状的性质，与目标无关：可行集无界不等于问题无下界，只有 $\boldsymbol{c}^{\mathsf{T}}\boldsymbol{d} < 0$ 时目标才沿它趋于 $-\infty$。图 2.7的 (b) 与 (c) 用的正是同一个可行域。表 2.3对比了这两种现象。

	退化基	无界可行方向
代数表现	基分量取零	$\boldsymbol{u} \le \mathbf{0}$
步长	可能 $\alpha^\star = 0$	没有上限
几何含义	多余约束过同一顶点	可行集沿射线无界
对目标的影响	换基后点和目标值不变	$\boldsymbol{c}^{\mathsf{T}}\boldsymbol{d} < 0$ 时无下界

表 2.3　退化基与无界可行方向的对比。

2.3 线性规划的对偶

有人告诉我们，车间问题的最优解是 $(2,2)$，最大利润是 10。检查可行性只需代入约束，难的是确认没有更好的产量。怎样给出一份不依赖求解过程、能当场核对的最优性证据？答案来自第 1章用过的办法，把约束加起来，只是这次要系统地做。

给约束配权重　把工时约束乘以 $u_1 \ge 0$，原料约束乘以 $u_2 \ge 0$，再相加。权重非负，不等号方向不变，得到

$$(u_1 + 2u_2)x_1 + (u_1 + u_2)x_2 \le 4u_1 + 6u_2.$$

如果左边的系数“盖得住”利润系数，也就是

$$u_1 + 2u_2 \ge 3, \qquad u_1 + u_2 \ge 2,$$

那么由 $x_1, x_2 \ge 0$，任何可行产量的利润都不超过 $4u_1 + 6u_2$。

不同的权重给出不同的上界。下面四组权重都满足上述条件：

$$\boldsymbol{u} = (2,1) \to 14, \quad (3,0) \to 12, \quad (0,2) \to 12, \quad (1,1) \to 10.$$

最后一个上界 10 恰好等于 $(2,2)$ 的利润，所以 $(2,2)$ 最优。这一行计算不依赖任何算法，谁都可以复核。

权重可以读成资源的价格。设想有人想买下车间全部的工时和原料，出价 u_1, u_2。车间只在卖资源不比自己生产亏时才肯卖，这就是上面的两个不等式。买方希望总价 $4u_1 + 6u_2$ 尽量低，寻找最低总价就是寻找最紧的上界，于是有问题

$$\min_{u_1,u_2} \; 4u_1 + 6u_2 \quad \text{s.t.} \quad u_1 + 2u_2 \geq 3, \quad u_1 + u_2 \geq 2, \quad u_1, u_2 \geq 0. \tag{2.16}$$

图 2.12(a) 是这个问题的可行域，最低总价 10 在 $(1,1)$ 取得。图 2.12(b) 把两边的数放在同一条数轴上：每个产量的利润都在每个价格的总价左边，两者在 10 处相遇。这正是“上下界夹逼”。买卖的故事只用来说明不等式的方向，并不表示真有这样一个市场，价格只是一组使不等式成立的数。

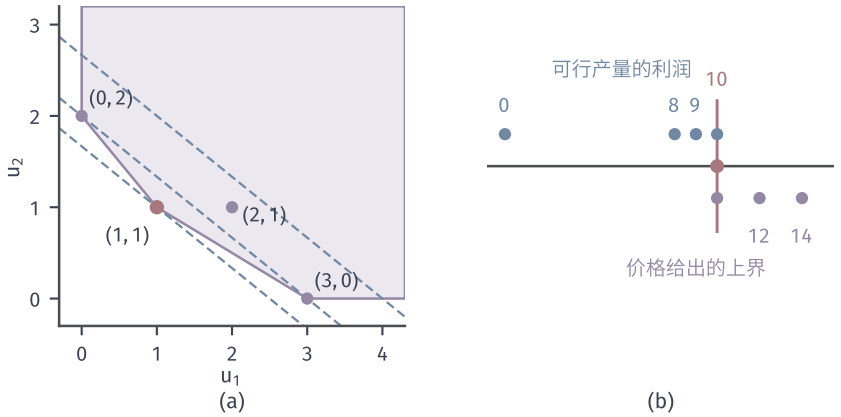


图 2.12　资源价格给出的上界。(a) 浅紫区域是满足式 (2.16)约束的价格 (u_1, u_2)，蓝色虚线是总价 $10, 12, 16$ 的等值线，红点 $(1,1)$ 是最低总价。(b) 数轴上方的蓝点是四个顶点的利润 $0, 8, 9, 10$，下方的紫点是四组价格的总价 $10, 12, 14$，红线标出两侧在 10 处相遇。

标准型的对偶问题　对标准型 (2.4)做同样的事。约束是等式，乘以任意实数都不改变等号，所以第 i 个等式的权重 y_i 没有符号限制。把等式按权重相加，得到

$$\boldsymbol{y}^{\top}\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}^{\top}\boldsymbol{y}.$$

我们想用左边给目标 $\boldsymbol{c}^{\top}\boldsymbol{x}$ 找下界。记两者系数的差为 $\boldsymbol{s} = \boldsymbol{c} - \boldsymbol{A}^{\top}\boldsymbol{y}$，则

$$\boldsymbol{c}^{\top}\boldsymbol{x} = \boldsymbol{y}^{\top}\boldsymbol{A}\boldsymbol{x} + \boldsymbol{s}^{\top}\boldsymbol{x} = \boldsymbol{b}^{\top}\boldsymbol{y} + \boldsymbol{s}^{\top}\boldsymbol{x}.$$

只要 $\boldsymbol{s} \geq \boldsymbol{0}$，由 $\boldsymbol{x} \geq \boldsymbol{0}$ 知 $\boldsymbol{s}^{\top}\boldsymbol{x} \geq 0$，于是 $\boldsymbol{b}^{\top}\boldsymbol{y}$ 就是下界。求最好的下界，就得到下面的问题。

定义 2.11 线性规划的对偶问题 标准型 (2.4)的对偶问题（dual problem）是

$$\max_{\boldsymbol{y}\in\mathbb{R}^m,\,\boldsymbol{s}\in\mathbb{R}^n} \ \boldsymbol{b}^{\top}\boldsymbol{y} \quad \text{s.t.} \quad \boldsymbol{A}^{\top}\boldsymbol{y}+\boldsymbol{s}=\boldsymbol{c}, \quad \boldsymbol{s}\geq\boldsymbol{0}, \tag{2.17}$$

其中 $\boldsymbol{y}$ 没有符号限制，$\boldsymbol{s}$ 称为**对偶松弛**（dual slack），最优值记为 $d^{\star}$。相对地，式 (2.4)称为**原始问题**（primal problem）。

对偶的每个 s_j 对应原始的一个变量 x_j，对偶的每个 y_i 对应原始的一个等式。把车间问题的标准型 (2.8)代入，得到

$$s_1=-3-y_1-2y_2, \quad s_2=-2-y_1-y_2, \quad s_3=-y_1, \quad s_4=-y_2.$$

$s_3,s_4\geq 0$ 说的是 $y_1,y_2\leq 0$，这个符号来自松弛变量的列。令 $\boldsymbol{u}=-\boldsymbol{y}$，$s_1,s_2\geq 0$ 就是式 (2.16)的两个不等式，对偶目标 $4y_1+6y_2$ 变为 $-(4u_1+6u_2)$。两种写法只差一个符号，因为这里把最大利润改成了最小化相反数。

定理 2.12 弱对偶 若 $\boldsymbol{x}$ 对原始问题可行，$(\boldsymbol{y},\boldsymbol{s})$ 对对偶问题可行，则

$$\boldsymbol{c}^{\top}\boldsymbol{x}-\boldsymbol{b}^{\top}\boldsymbol{y}=\boldsymbol{x}^{\top}\boldsymbol{s}\geq 0. \tag{2.18}$$

特别地 $d^{\star}\leq p^{\star}$；若 $\boldsymbol{x}^{\top}\boldsymbol{s}=0$，则 $\boldsymbol{x}$ 和 $(\boldsymbol{y},\boldsymbol{s})$ 分别是两个问题的最优解。

证明 把 $\boldsymbol{c}=\boldsymbol{A}^{\top}\boldsymbol{y}+\boldsymbol{s}$ 代入，再用 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$，得到

$$\boldsymbol{c}^{\top}\boldsymbol{x}=\boldsymbol{y}^{\top}\boldsymbol{A}\boldsymbol{x}+\boldsymbol{s}^{\top}\boldsymbol{x}=\boldsymbol{b}^{\top}\boldsymbol{y}+\boldsymbol{x}^{\top}\boldsymbol{s}.$$

两个向量都非负，所以 $\boldsymbol{x}^{\top}\boldsymbol{s}\geq 0$。

若 $\boldsymbol{x}^{\top}\boldsymbol{s}=0$，则 $\boldsymbol{c}^{\top}\boldsymbol{x}=\boldsymbol{b}^{\top}\boldsymbol{y}$。任何其他原始可行点的目标值都不小于 $\boldsymbol{b}^{\top}\boldsymbol{y}$，任何其他对偶可行点的目标值都不大于 $\boldsymbol{c}^{\top}\boldsymbol{x}$，所以两者都最优。 ■

这个结论称为**弱对偶**（weak duality）。差 $\boldsymbol{c}^{\top}\boldsymbol{x}-\boldsymbol{b}^{\top}\boldsymbol{y}$ 称为这对可行点的**对偶间隙**（duality gap）。它同时控制了两边：$\boldsymbol{c}^{\top}\boldsymbol{x}-p^{\star}$ 不超过间隙，$d^{\star}-\boldsymbol{b}^{\top}\boldsymbol{y}$ 也不超过间隙。

条件 $\boldsymbol{s}\geq\boldsymbol{0}$ 不是形式要求。取价格 $\boldsymbol{u}=(1/2,1)$，它满足 $u_1+u_2\geq 2$，却违反 $u_1+2u_2\geq 3$，因为左边是 $5/2$。它算出的“上界”是 $4u_1+6u_2=8$，比真实的最大利润 10 还小。对偶可行性没有检查，这个数就什么也不说明。

符号规则 其他形式的原始问题对应什么样的对偶？不必记表，每次回到“加权相加后不等号方向要对”即可。表 2.4是最小化问题的结果。例如 $\boldsymbol{g}^{\top}\boldsymbol{x} \geq h$ 要用来给目标找下界，权重必须非负；x_j 可正可负时，$s_j x_j$ 要始终非负，只能 $s_j = 0$。

原始（最小化）	对偶（最大化）
等式约束	权重 y_i 无符号限制
$\geq$ 约束	$y_i \geq 0$
$\leq$ 约束	$y_i \leq 0$
$x_j \geq 0$	$s_j \geq 0$
x_j 自由	$s_j = 0$
$x_j \leq 0$	$s_j \leq 0$

表 2.4 最小化问题的对偶符号规则，其中 $s_j = c_j - \boldsymbol{a}_j^{\top}\boldsymbol{y}$。

对偶的对偶回到原问题。把式 (2.17)中的 $\boldsymbol{y}$ 写成 $\boldsymbol{y}^{+} - \boldsymbol{y}^{-}$，并把目标取相反数，它成为变量 $\boldsymbol{y}^{+}, \boldsymbol{y}^{-}, \boldsymbol{s}$ 上的标准型：

$$\min\ -\boldsymbol{b}^{\top}\boldsymbol{y}^{+} + \boldsymbol{b}^{\top}\boldsymbol{y}^{-} \quad \text{s.t.} \quad \boldsymbol{A}^{\top}\boldsymbol{y}^{+} - \boldsymbol{A}^{\top}\boldsymbol{y}^{-} + \boldsymbol{s} = \boldsymbol{c}.$$

按定义写出它的对偶，权重记为 $\boldsymbol{z}$，三组列分别给出三组不等式：

$$\boldsymbol{A}\boldsymbol{z} \leq -\boldsymbol{b}, \qquad -\boldsymbol{A}\boldsymbol{z} \leq \boldsymbol{b}, \qquad \boldsymbol{z} \leq \boldsymbol{0}.$$

前两组合起来是 $\boldsymbol{A}\boldsymbol{z} = -\boldsymbol{b}$。令 $\boldsymbol{x} = -\boldsymbol{z}$，这个对偶就是在 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$，$\boldsymbol{x} \geq \boldsymbol{0}$ 上最大化 $-\boldsymbol{c}^{\top}\boldsymbol{x}$，也就是原来的标准型。两个问题的地位因此是对称的，表 2.5用车间问题对照了它们的成分。

	原始：决定产量	对偶：决定价格
变量	x_j，产品 j 的产量	u_i，资源 i 的单价
约束	每种资源够用	每种产品的资源价值不低于利润
目标	最大化利润	最小化资源总价
相互给出	最大利润的下界	最大利润的上界

表 2.5 车间问题的原始问题与对偶问题。原始的一条约束对应对偶的一个变量，原始的一个变量对应对偶的一条约束。

Farkas 引理 弱对偶只说明下界不超过最优值，下界能否恰好等于最优值？这要靠一个判定等式组可解性的定理。先看几何。$\{\boldsymbol{A}\boldsymbol{x} : \boldsymbol{x} \geq \boldsymbol{0}\}$ 是 $\boldsymbol{A}$ 的各列按非负系数组合得到的锥，记作 $\boldsymbol{K}$，等式组 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$，$\boldsymbol{x} \geq \boldsymbol{0}$ 有解就是 $\boldsymbol{b} \in \boldsymbol{K}$。

如果 $\boldsymbol{b}$ 在锥外，直觉告诉我们，应该有一个过原点的超平面把整个锥和 $\boldsymbol{b}$ 隔在两侧。这个超平面的法向量 $\boldsymbol{z}$ 就是不可解的证据。

定理 2.13　Farkas 引理　给定 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 和 $\boldsymbol{b} \in \mathbb{R}^m$，下面两个系统恰有一个有解：

$$\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}, \quad \boldsymbol{x} \geq \boldsymbol{0}; \tag{2.19}$$

$$\boldsymbol{A}^{\top}\boldsymbol{z} \geq \boldsymbol{0}, \quad \boldsymbol{b}^{\top}\boldsymbol{z} < 0. \tag{2.20}$$

证明　两个系统不能同时有解，否则

$$0 > \boldsymbol{b}^{\top}\boldsymbol{z} = \boldsymbol{x}^{\top}\boldsymbol{A}^{\top}\boldsymbol{z} \geq 0.$$

现在设式 (2.19)无解，即 $\boldsymbol{b} \notin \boldsymbol{K}$，要构造 $\boldsymbol{z}$。先证 $\boldsymbol{K}$ 是闭集。任取 $\boldsymbol{v} \in \boldsymbol{K}$，在 $\boldsymbol{v} = \boldsymbol{A}\boldsymbol{x}$（$\boldsymbol{x} \geq \boldsymbol{0}$）的写法中取正分量最少的一种。若正分量对应的列线性相关，可以像引理 2.7那样沿零空间方向移动，再消去一个正分量，矛盾。所以这些列线性无关，$\boldsymbol{K}$ 是有限多个集合 $\boldsymbol{K}_J$ 的并，每个 $\boldsymbol{K}_J$ 由一组线性无关的列 $\boldsymbol{A}_J$ 按非负系数组合而成。

设 $\boldsymbol{A}_J\boldsymbol{x}^{(k)} \to \boldsymbol{v}$，$\boldsymbol{x}^{(k)} \geq \boldsymbol{0}$。$\boldsymbol{A}_J$ 列满秩，所以

$$\boldsymbol{x}^{(k)} = (\boldsymbol{A}_J^{\top}\boldsymbol{A}_J)^{-1}\boldsymbol{A}_J^{\top}\boldsymbol{A}_J\boldsymbol{x}^{(k)}$$

收敛，极限非负，于是 $\boldsymbol{v} \in \boldsymbol{K}_J$。有限个闭集的并是闭集，$\boldsymbol{K}$ 闭。

再取 $\boldsymbol{K}$ 中离 $\boldsymbol{b}$ 最近的点。任取 $\boldsymbol{v}_0 \in \boldsymbol{K}$，$\boldsymbol{K}$ 与以 $\boldsymbol{b}$ 为中心、半径 $\|\boldsymbol{v}_0 - \boldsymbol{b}\|_2$ 的闭球之交是非空紧集，连续函数 $\|\boldsymbol{v} - \boldsymbol{b}\|_2^2$ 在其上取得最小值，这个最小点 $\hat{\boldsymbol{v}}$ 就是 $\boldsymbol{K}$ 上的最小点。令

$$\boldsymbol{z} = \hat{\boldsymbol{v}} - \boldsymbol{b} \neq \boldsymbol{0}.$$

$\boldsymbol{K}$ 是锥，所以对每个 $t \geq 0$，$t\hat{\boldsymbol{v}} \in \boldsymbol{K}$。函数 $\phi(t) = \|t\hat{\boldsymbol{v}} - \boldsymbol{b}\|_2^2$ 在 $t = 1$ 取最小，导数 $\phi'(1)$ 为零，也就是 $2\hat{\boldsymbol{v}}^{\top}\boldsymbol{z} = 0$，所以（$\hat{\boldsymbol{v}} = \boldsymbol{0}$ 时等式自然成立）

$$\hat{\boldsymbol{v}}^{\top}\boldsymbol{z} = 0.$$

对每一列 $\boldsymbol{a}_j$ 和 $t \geq 0$，点 $\hat{\boldsymbol{v}} + t\boldsymbol{a}_j$ 也在 $\boldsymbol{K}$ 中，所以它到 $\boldsymbol{b}$ 的距离平方在 $t = 0$ 处的右导数 $2\boldsymbol{a}_j^{\top}\boldsymbol{z}$ 非负，得到

$$\boldsymbol{a}_j^{\top}\boldsymbol{z} \geq 0.$$

这就是 $\boldsymbol{A}^{\top}\boldsymbol{z} \geq \boldsymbol{0}$。最后，由 $\boldsymbol{b} = \hat{\boldsymbol{v}} - \boldsymbol{z}$ 和 $\hat{\boldsymbol{v}}^{\top}\boldsymbol{z} = 0$，

$$\boldsymbol{b}^{\top}\boldsymbol{z} = \hat{\boldsymbol{v}}^{\top}\boldsymbol{z} - \|\boldsymbol{z}\|_2^2 = -\|\boldsymbol{z}\|_2^2 < 0.$$

■

满足式 (2.20)的 $\boldsymbol{z}$ 是不可行的证书。核对它只需一次矩阵乘法：若有可行的 $\boldsymbol{x}$，$\boldsymbol{b}^{\top}\boldsymbol{z} = \boldsymbol{x}^{\top}\boldsymbol{A}^{\top}\boldsymbol{z}$ 是非负数的乘积之和，不可能为负。

用车间矩阵的前两列看两种情形，这两列是

$$\boldsymbol{a}_1 = (1,2)^{\top}, \qquad \boldsymbol{a}_2 = (1,1)^{\top}.$$

右端为 $\boldsymbol{b} = (4,6)^{\top}$ 时，$\boldsymbol{x} = (2,2)^{\top}$ 是解，如图 2.13(a)。右端换成 $\boldsymbol{b}' = (1,0)^{\top}$ 时，解方程组得 $x_1 = -1$，$x_2 = 2$，没有非负解。按证明构造：锥 $\boldsymbol{K}$ 上离 $\boldsymbol{b}'$ 最近的点在 $\boldsymbol{a}_2$ 这条边上，

$$\hat{\boldsymbol{v}} = \left(\frac{1}{2}, \frac{1}{2}\right)^{\top}, \qquad \boldsymbol{z} = \hat{\boldsymbol{v}} - \boldsymbol{b}' = \left(-\frac{1}{2}, \frac{1}{2}\right)^{\top}.$$

逐项核对：

$$\boldsymbol{a}_1^{\top}\boldsymbol{z} = \frac{1}{2}, \qquad \boldsymbol{a}_2^{\top}\boldsymbol{z} = 0, \qquad (\boldsymbol{b}')^{\top}\boldsymbol{z} = -\frac{1}{2}.$$

这组权重的含义也很直接：第二个等式减第一个等式，得到 $x_1 = -1$，与 $x_1 \geq 0$ 矛盾。

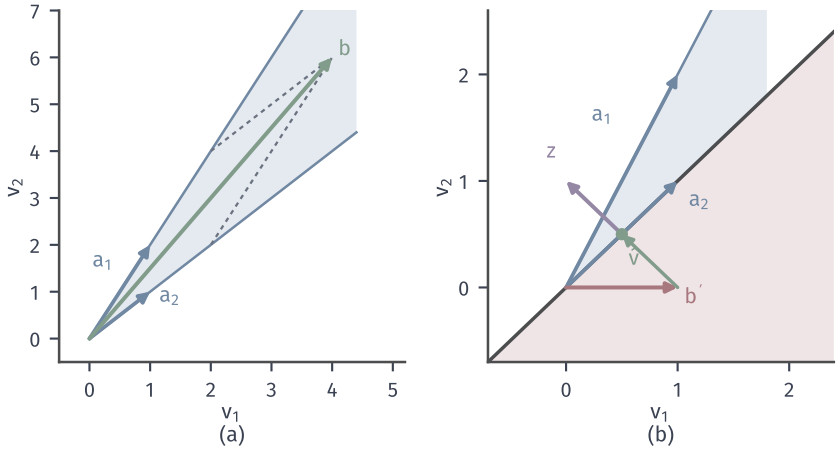


图 2.13 Farkas 引理的几何。蓝色箭头是两列 $\boldsymbol{a}_1, \boldsymbol{a}_2$，浅蓝区域是它们张成的锥。(a) $\boldsymbol{b} = (4,6)^{\top}$ 在锥内，灰色虚线是 $\boldsymbol{b} = 2\boldsymbol{a}_1 + 2\boldsymbol{a}_2$ 的分解。(b) $\boldsymbol{b}' = (1,0)^{\top}$ 在锥外，绿点 $\hat{\boldsymbol{v}}$ 是锥上最近的点，紫色箭头 $\boldsymbol{z} = \hat{\boldsymbol{v}} - \boldsymbol{b}'$ 是分离超平面（深灰线）的法向量；浅红半平面是 $\boldsymbol{z}^{\top}\boldsymbol{v} < 0$ 的一侧，$\boldsymbol{b}'$ 在其中，整个锥在另一侧。

强对偶 现在回答开头的问题：只要原始问题可行且最优值有限，最好的下界就等于最优值，这个结论称为**强对偶**（strong duality）。

定理 2.14 线性规划强对偶 若标准型 (2.4)可行且最优值 $p^\star$ 有限，则对偶问题 (2.17)有最优解，并且

$$d^\star = p^\star. \tag{2.21}$$

证明 只需找到 $(\boldsymbol{y}, \boldsymbol{s})$ 对偶可行，且 $\boldsymbol{b}^\top \boldsymbol{y} \geq p^\star$，弱对偶就会迫使等号成立。把要求写成带非负变量的等式组，引入 $r \geq 0$，令 $\boldsymbol{y} = \boldsymbol{y}^+ - \boldsymbol{y}^-$：

$$\boldsymbol{A}^\top \boldsymbol{y}^+ - \boldsymbol{A}^\top \boldsymbol{y}^- + \boldsymbol{s} = \boldsymbol{c}, \qquad \boldsymbol{b}^\top \boldsymbol{y}^+ - \boldsymbol{b}^\top \boldsymbol{y}^- - r = p^\star.$$

假设这个系统没有非负解。由 Farkas 引理，存在 $\boldsymbol{z} \in \mathbb{R}^n$ 和 $\sigma \in \mathbb{R}$，对系数矩阵的四组列分别满足

$$\boldsymbol{A}\boldsymbol{z} + \sigma \boldsymbol{b} \geq \boldsymbol{0}, \quad -\boldsymbol{A}\boldsymbol{z} - \sigma \boldsymbol{b} \geq \boldsymbol{0}, \quad \boldsymbol{z} \geq \boldsymbol{0}, \quad -\sigma \geq 0,$$

并且右端的内积为负，即 $\boldsymbol{c}^\top \boldsymbol{z} + \sigma p^\star < 0$。记 $\tau = -\sigma \geq 0$，前两式合起来得到

$$\boldsymbol{A}\boldsymbol{z} = \tau \boldsymbol{b}, \qquad \boldsymbol{z} \geq \boldsymbol{0}, \qquad \boldsymbol{c}^\top \boldsymbol{z} < \tau p^\star.$$

若 $\tau > 0$，则 $\boldsymbol{z}/\tau$ 是原始可行点，目标值小于 $p^\star$，矛盾。若 $\tau = 0$，则 $\boldsymbol{A}\boldsymbol{z} = \boldsymbol{0}$，$\boldsymbol{z} \geq \boldsymbol{0}$，$\boldsymbol{c}^\top \boldsymbol{z} < 0$。任取可行点 $\hat{\boldsymbol{x}}$，$\hat{\boldsymbol{x}} + t\boldsymbol{z}$ 对一切 $t \geq 0$ 可行，目标趋于 $-\infty$，与 $p^\star$ 有限矛盾。

所以系统有解，得到对偶可行的 $(\boldsymbol{y}, \boldsymbol{s})$ 和 $\boldsymbol{b}^\top \boldsymbol{y} = p^\star + r \geq p^\star$。由弱对偶，$\boldsymbol{b}^\top \boldsymbol{y} \leq p^\star$，因此 $\boldsymbol{b}^\top \boldsymbol{y} = p^\star$，这个 $(\boldsymbol{y}, \boldsymbol{s})$ 是对偶最优解。 ■

证明里两种情形各用了一个条件：$\tau > 0$ 时用到 $p^\star$ 是下确界，$\tau = 0$ 时用到问题可行且有下界。线性规划的强对偶不需要其他条件。一般的凸问题则不然，第 18章会在 Lagrange 函数的框架下说明，零间隙还需要额外的假设。

互补松弛与零间隙证书 强对偶告诉我们证书一定存在，弱对偶告诉我们怎样核对它。把两者合起来，就是线性规划的最优性判别。

定理 2.15　零间隙证书与互补松弛　设标准型的 $\boldsymbol{x}$ 和 $(\boldsymbol{y},\boldsymbol{s})$ 满足

$$\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b},\quad \boldsymbol{x}\ge\boldsymbol{0},\qquad \boldsymbol{A}^{\top}\boldsymbol{y}+\boldsymbol{s}=\boldsymbol{c},\quad \boldsymbol{s}\ge\boldsymbol{0}. \tag{2.22}$$

则下面三条等价：$\boldsymbol{x}$ 和 $(\boldsymbol{y},\boldsymbol{s})$ 分别是原始、对偶最优解；$\boldsymbol{c}^{\top}\boldsymbol{x}=\boldsymbol{b}^{\top}\boldsymbol{y}$；对每个 j，

$$x_j s_j = 0. \tag{2.23}$$

证明　由式 (2.18)，第二条等价于 $\boldsymbol{x}^{\top}\boldsymbol{s}=0$。$\boldsymbol{x}^{\top}\boldsymbol{s}$ 是非负数 $x_j s_j$ 之和，为零当且仅当每一项为零，这就是第三条。第二条推出第一条是弱对偶的结论。反过来若两者都最优，由强对偶知两个最优值相等，得到第二条。 ■

式 (2.23)称为**互补松弛**（complementary slackness）。它说的是，每对 (x_j,s_j) 中至少有一个为零。用价格的语言：正在生产的产品没有多余的利润，有多余的资源价格为零。第 4章的算法正是围绕这组方程组织的。

有了最优解的猜测，互补松弛还能反过来求出价格。车间问题中 $\boldsymbol{x}^{\star}=(2,2,0,0)^{\top}$，$x_1,x_2>0$ 要求 $s_1=s_2=0$，也就是

$$y_1+2y_2=-3,\qquad y_1+y_2=-2.$$

解得 $\boldsymbol{y}=(-1,-1)^{\top}$，再算出其余的对偶松弛：

$$s_3=-y_1=1,\qquad s_4=-y_2=1.$$

$\boldsymbol{s}=(0,0,1,1)^{\top}\ge\boldsymbol{0}$，对偶可行，并且 $\boldsymbol{b}^{\top}\boldsymbol{y}=-10=\boldsymbol{c}^{\top}\boldsymbol{x}^{\star}$。这一对点就是最优性的完整证书。

不是最优的顶点通不过同样的检查。取 $(3,0)$，即 $\boldsymbol{x}=(3,0,1,0)^{\top}$。$x_1,x_3>0$ 要求 $s_1=s_3=0$，于是

$$y_1=0,\qquad y_2=-\frac{3}{2},\qquad s_2=-2-y_1-y_2=-\frac{1}{2}<0.$$

满足互补松弛的 $\boldsymbol{y}$ 只有这一个，它不对偶可行，所以 $(3,0)$ 不是最优解。

这个判别有直接的几何含义。回到平面上，顶点处的活动约束有各自的外法向量。互补松弛说的是，利润向量 $\boldsymbol{p}$ 是活动约束法向量的非负组合。图 2.14在两个顶点上比较：$(2,2)$ 处 $\boldsymbol{p}=1\cdot\boldsymbol{n}_1+1\cdot\boldsymbol{n}_2$，系数正是价格 $\boldsymbol{u}=(1,1)$；$(3,0)$ 处活动约束的法向量是 $\boldsymbol{n}_2=(2,1)$ 和 $\boldsymbol{n}_3=(0,-1)$，分解

$$\begin{bmatrix}3\\2\end{bmatrix}=\frac{3}{2}\begin{bmatrix}2\\1\end{bmatrix}-\frac{1}{2}\begin{bmatrix}0\\-1\end{bmatrix}$$

含负系数，$\boldsymbol{p}$ 在锥外，负系数 $-1/2$ 正是上面算出的 s_2。

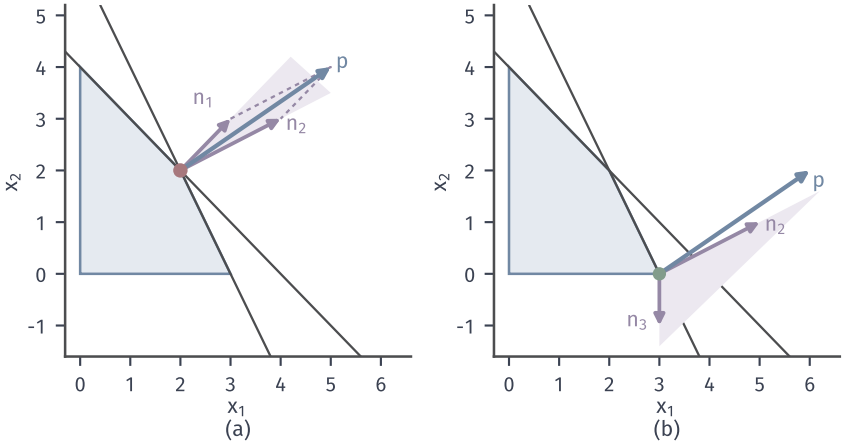


图 2.14　互补松弛的几何。紫色箭头是顶点处活动约束的外法向量，浅紫区域是它们张成的锥，蓝色箭头是利润向量 $\mathbf{p}=(3,2)$。(a) $(2,2)$ 处，$\mathbf{p}$ 在锥内，是两个法向量的正组合（紫色虚线），该顶点最优。(b) $(3,0)$ 处，$\mathbf{p}$ 在锥外，该顶点不是最优解。

价格还有边际价值的含义。把工时从 4 增加到 5，新的最优产量是 $(1,4)$，利润 11，恰好增加 $u_1=1$。这种关系只在一定范围内成立，第 3章固定最优基时会算出这个范围。

三种结局的证书　线性规划只有三种结局，每种都有可以独立核对的证据。有最优解时，证书是满足式 (2.22)和式 (2.23)的一对点。不可行时，证书是满足式 (2.20)的 $\boldsymbol{z}$。无下界时，证书是一个可行点加上满足下式的方向：

$$\boldsymbol{A}\boldsymbol{d}=\mathbf{0},\qquad \boldsymbol{d}\geq\mathbf{0},\qquad \boldsymbol{c}^{\mathsf{T}}\boldsymbol{d}<0. \tag{2.24}$$

两个问题的结局也互相牵制。原始无下界时，对偶不可能有可行点，否则弱对偶会给出有限下界，所以对偶不可行。由对称性，对偶无上界时原始不可行。两者都不可行的情形确实存在，例如

$$\min\ -x_1-x_2\quad\text{s.t.}\quad x_1-x_2=1,\quad -x_1+x_2=1,\quad \boldsymbol{x}\geq\mathbf{0}.$$

两个等式相加得到 $0=2$，原始不可行；对偶约束 $y_1-y_2\leq -1$ 和 $-y_1+y_2\leq -1$ 相加得到 $0\leq -2$，对偶也不可行。

这个例子中方向 $\boldsymbol{d}=(1,1)^{\mathsf{T}}$ 满足式 (2.24)，但没有可行的起点，它什么也说明不了。所以报告无下界时，可行点和方向缺一不可。表 2.6列出全部可能的组合。

原始＼对偶	有最优解	无上界	不可行
有最优解	可能，且 $p^\star = d^\star$	不可能	不可能
无下界	不可能	不可能	可能
不可行	不可能	可能	可能

表 2.6 原始问题与对偶问题结局的组合。两个“有最优解”以外的“不可能”分别由强对偶、弱对偶和对称性得到。

图中的流问题 第 2.1节的网络流实例能让对偶问题有具体的含义。关联矩阵 (2.3)的列是 $\boldsymbol{a}_{i,j} = \boldsymbol{e}_i - \boldsymbol{e}_j$，所以 $\boldsymbol{a}_{i,j}^{\top}\boldsymbol{y} = y_i - y_j$，对偶约束是逐弧的不等式，这里 $\boldsymbol{e}_i$ 是第 i 个单位向量：

$$s_{i,j} = c_{i,j} - (y_i - y_j) \geq 0. \tag{2.25}$$

y_i 是节点上的数, 可以读成 “从节点 i 把一单位货物送到终点的费用估计”, 这种量通常称为节点势。式 (2.25)要求沿弧走一步，费用估计的下降不能超过这条弧的费用。对偶目标 $\boldsymbol{b}^{\top}\boldsymbol{y} = y_1 - y_4$ 是起点和终点的势差。

矩阵的四行线性相关, 这时 $\boldsymbol{y}$ 可以整体加一个常数而不影响任何 $y_i - y_j$, 所以取 $y_4 = 0$，这相当于删去第四行。令最短路 $1 \to 2 \to 3 \to 4$ 上的三条弧都取等号，得到

$$y_3 = 2, \qquad y_2 = y_3 + 1 = 3, \qquad y_1 = y_2 + 2 = 5.$$

其余两条弧的对偶松弛为

$$s_{1,3} = 5 - (5 - 2) = 2, \qquad s_{2,4} = 6 - (3 - 0) = 3.$$

路径 $1 \to 2 \to 3 \to 4$ 的流量为 1, 总费用 $2+1+2 = 5$, 而 $\boldsymbol{b}^{\top}\boldsymbol{y} = 5-0 = 5$, 两者相等。图 2.15显示了这份证书，互补松弛说的是：只有 $s_{i,j} = 0$ 的弧上才允许有流量。

2.1 线性规划的表述
2.2 基本可行解
2.3 线性规划的对偶
2.4 线性松弛
2.5 本章小结

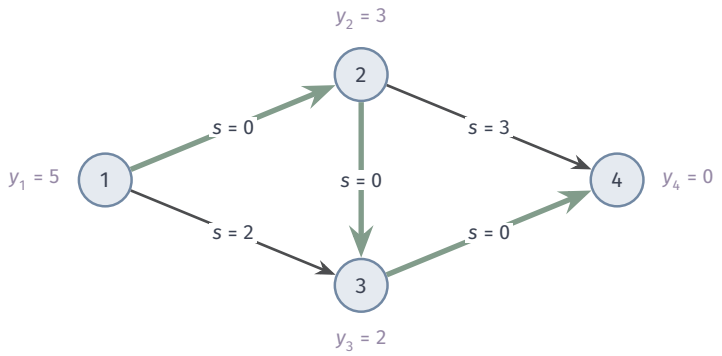


图 2.15 图 2.1实例的对偶证书。节点旁的紫色数字是节点势 y_i，弧旁是对偶松弛 $s_{i,j}$。绿色粗线是流量为 1 的最短路，这些弧上 $s_{i,j} = 0$，其余两条弧无流量。

这份证书正是图算法中逐弧检查的最优性条件。最短路的逐弧不等式和最小费用流的节点势都是对偶可行性，可参考卷三第 3 章“最短路”；最大流最小割定理也是这种配对关系的特例，割给出流量的上界，可参考卷三第 5 章“最大流与最小割”。一般凸问题的对偶由第 18章用 Lagrange 函数统一处理，线性规划是其中条件最宽松的情形。

2.4 线性松弛

产品如果只能整批生产，变量就必须取整数。于是要问：去掉整数要求之后，连续问题的解和最优值能告诉我们整数问题的什么？回答分三层：最优值总能给出一个界；在特殊的矩阵结构下，顶点自动是整数；一般情形下，连续解还要经过专门论证的处理，才能变成原问题的可行解。

整数问题与它的松弛 在标准型或不等式形式的线性规划上再要求变量取整数，就得到**整数线性规划**（integer linear programming）。设

$$p_{\mathrm{I}} = \min\{\boldsymbol{c}^{\top}\boldsymbol{x} : \boldsymbol{x} \in \boldsymbol{C},\ \boldsymbol{x} \in \mathbb{Z}^n\}, \qquad p_{\mathrm{R}} = \min\{\boldsymbol{c}^{\top}\boldsymbol{x} : \boldsymbol{x} \in \boldsymbol{C}\}. \tag{2.26}$$

去掉整数要求后的问题称为原问题的**线性松弛**（linear relaxation）。这里的 $\boldsymbol{C}$ 可以是任何多面体。

松弛扩大了可行集，最小化时最优值只会变小或不变。这是下面定理的全部内容，也是松弛提供的最基本的信息。

定理 2.16 松弛给出下界 若整数问题可行且松弛的最优值有限，则

$$p_{\mathrm{R}} \le p_{\mathrm{I}}. \tag{2.27}$$

若松弛有一个最优解是整数向量，则它也是整数问题的最优解，且等号成立。

证明 整数问题的可行点都在 $\boldsymbol{C}$ 中，在较大的集合上取最小值不会更大，得到式 (2.27)。若松弛的最优解 $\boldsymbol{x}$ 是整数向量，它对整数问题可行，于是

$$p_{\mathrm{I}} \le \boldsymbol{c}^{\top}\boldsymbol{x} = p_{\mathrm{R}}.$$

再与式 (2.27)合并，等号成立。 ■

用一个具体的整数问题走一遍。把车间的原料增加到 7 份，利润系数改成 $(3,1)$，并要求产量取整数：

$$\max\ 3x_1 + x_2 \quad \text{s.t.} \quad x_1 + x_2 \le 4, \quad 2x_1 + x_2 \le 7, \quad \boldsymbol{x} \ge \boldsymbol{0}, \quad \boldsymbol{x} \in \mathbb{Z}^2.$$

松弛的四个顶点是 $(0,0),(7/2,0),(3,1),(0,4)$，对应的利润依次是

$$0, \qquad \frac{21}{2}, \qquad 10, \qquad 4.$$

所以松弛的最优解是 $(7/2,0)$，最优利润 $21/2$。按 x_1 的取值逐个比较可行的整数点，x_1 固定时 x_2 取最大，四种情形的利润依次是

$$x_1 = 0:\ 4, \qquad x_1 = 1:\ 6, \qquad x_1 = 2:\ 8, \qquad x_1 = 3:\ 10.$$

$x_1 \ge 4$ 时原料不够，所以整数问题的最优解是 $(3,1)$，利润 10。这里是最大化，松弛给出的是上界，写成最小化 $-3x_1 - x_2$ 时，就是 $p_{\mathrm{R}} = -21/2 \le -10 = p_{\mathrm{I}}$。

舍入不是免费的 最直接的想法是把松弛解舍入成整数。图 2.16显示这个想法的问题。$(7/2,0)$ 向上取整得到 $(4,0)$，用掉 8 份原料，不可行。向下取整得到 $(3,0)$，可行，利润只有 9，也不是最优。真正的最优解 $(3,1)$ 在 x_2 上离松弛解差了一整个单位，它不是任何一种舍入的结果。

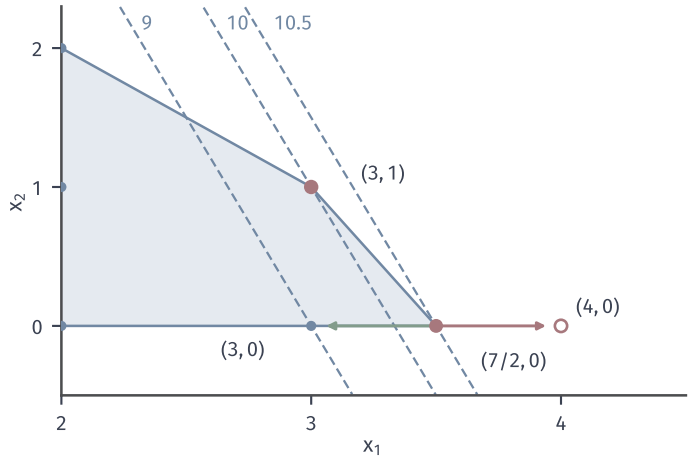


图 2.16 舍入松弛解。蓝点是可行的整数点，蓝色虚线是利润 9、10、10.5 的等值线。松弛最优解 $(7/2, 0)$（红点，位于右下顶点）向右舍入到不可行的 $(4, 0)$（红色空心点），向左舍入到利润只有 9 的 $(3, 0)$；整数最优解是红点 $(3, 1)$。

松弛最优值虽然不直接给出解，却给出了一个证明的工具。目标系数和变量都是整数时，p_{I} 也是整数，所以下界可以向上取整：

$$p_{\mathrm{I}} \geq \lceil p_{\mathrm{R}} \rceil = \left\lceil -\frac{21}{2} \right\rceil = -10.$$

而 $(3, 1)$ 的目标值恰好是 -10，这就证明了它是最优的，不需要枚举。一般情形下，松弛最优值和某个可行整数点的目标值夹出的区间，是对整数最优值的一个估计，这个区间的宽度取决于松弛有多紧。

$p_{\mathrm{I}} - p_{\mathrm{R}}$ 称为这个实例的**整数间隙**（integrality gap），这里是 $1/2$。整数间隙衡量松弛对原问题的逼近程度，与求解松弛的算法无关。

整数顶点：全幺模 既然线性规划的最优解可以在顶点取得，顶点若都是整数，整数约束就没有额外的代价。对比图 2.17的两个多面体，它们的矩阵相同，右端不同：原料为 6 时四个顶点都是整数，原料为 7 时出现了分数顶点 $(7/2, 0)$。顶点是否整数，到底由什么决定？

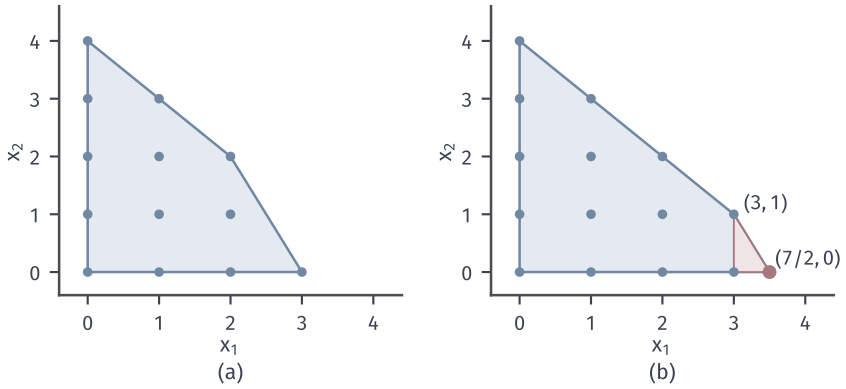


图 2.17 相同的约束矩阵，不同的右端。蓝点是可行的整数点。(a) 原料为 6，四个顶点都是整数。(b) 原料为 7，右下顶点 $(7/2, 0)$ 是分数，红色小三角形是松弛比全体整数点的凸包多出的部分。

答案在定义基本解的式 (2.11)里。由 Cramer 法则，

$$(\boldsymbol{x}_B)_i = \frac{\det \boldsymbol{A}_B^{(i)}}{\det \boldsymbol{A}_B},$$

其中 $\boldsymbol{A}_B^{(i)}$ 是把 $\boldsymbol{A}_B$ 的第 i 列换成 $\boldsymbol{b}$ 得到的矩阵。$\boldsymbol{A}$ 和 $\boldsymbol{b}$ 都是整数时分子是整数，分数只能来自分母。如果基矩阵的行列式总是 ± 1，顶点就一定是整数。图 2.17(b) 的分数顶点来自基 $\{1, 3\}$，它的行列式是 -2，分母是 2，而 7 是奇数；$b_2 = 6$ 时 $6/2$ 仍是整数，分母恰好被消去。

定义 2.17 全幺模矩阵 若矩阵 $\boldsymbol{A}$ 的每个方子矩阵的行列式都属于 $\{0, 1, -1\}$，就称 $\boldsymbol{A}$ 是**全幺模矩阵**（totally unimodular matrix）。

特别地，全幺模矩阵的元素都只能是 $0, \pm 1$。这个条件对所有方子矩阵提出要求，而不只是对基矩阵，这样它才能在加松弛变量、删冗余行这些改写后保持下来。

定理 2.18 全幺模与整数顶点 设 $\boldsymbol{A}$ 满行秩且全幺模，$\boldsymbol{b}$ 是整数向量。则 $\boldsymbol{C}$ 的每个基本可行解都是整数向量。若问题可行且最优值有限，则存在整数最优解，从而

$$p_{\mathrm{I}} = p_{\mathrm{R}}. \tag{2.28}$$

证明 任取基 B。$\boldsymbol{A}_B$ 是可逆的方子矩阵，所以 $\det \boldsymbol{A}_B = \pm 1$。由 Cramer 法则，$\boldsymbol{x}_B$ 的每个分量都是整数行列式除以 ± 1，是整数。第二句由定理 2.8和定理 2.16得到。 ■

不等式形式也可以用。若 $\boldsymbol{A}$ 全幺模，则 $[\boldsymbol{A}\ \boldsymbol{I}]$ 也全幺模：它的方子矩阵若含单位矩阵的列，这一列至多有一个非零元，按这一列展开，行列式化成 $\boldsymbol{A}$ 的更小子矩阵的行列式，或者为零。于是不等式约束 $\boldsymbol{A}\boldsymbol{x} \le \boldsymbol{b}$，$\boldsymbol{x} \ge \boldsymbol{0}$ 在加了松弛变量之后满足定理的条件，变量的整数上界也可以同样处理。

定理的每个条件都起作用。$\boldsymbol{A}$ 全幺模但 $\boldsymbol{b}$ 不是整数时，顶点就不是整数，例如 $x_1 \le 1/2$，$x_1 \ge 0$ 的顶点 $1/2$。反过来，全幺模只是充分条件：车间矩阵含元素 2，不是全幺模的，但 $b_2 = 6$ 时顶点恰好都是整数。

定理说的是基本可行解，不是所有最优解。图 2.8(b) 那样有整条最优边的情形，边上的点可以不是整数，所以要得到整数解，必须取到顶点。

网络矩阵是全幺模的 最重要的全幺模矩阵来自有向图。这正是图上的最短路、最大流、最小费用流可以用连续方法求整数解的原因。

定理 2.19 关联矩阵全幺模 设矩阵的每一列至多有一个 $+1$、至多有一个 -1，其余元素为零。有向图的关联矩阵就是这样的矩阵。这样的矩阵是全幺模的。

证明 对方子矩阵 $\boldsymbol{D}$ 的阶数 k 归纳。$k = 1$ 时元素属于 $\{0, \pm 1\}$。设 $k > 1$，$\boldsymbol{D}$ 的列也满足“至多一个 $+1$、至多一个 -1”，分三种情形。

若某列全为零，$\det \boldsymbol{D} = 0$。若某列恰有一个非零元，按这一列展开，$\det \boldsymbol{D}$ 等于 $\pm$ 一个 $k-1$ 阶子矩阵的行列式，由归纳假设属于 $\{0, \pm 1\}$。若每一列都恰有一个 $+1$ 和一个 -1，则所有行相加是零向量，$\det \boldsymbol{D} = 0$。 ■

网络矩阵 (2.3)不是满行秩的，删去一行之后仍是全幺模矩阵的子矩阵，定理 2.18可以使用。所以整数供需量、整数容量的最小费用流问题，线性规划的顶点解就是整数流，这正是第 2.3节实例中的最短路自动取 0 或 1 的原因。

二部图的情形也可以化成这个定理。把无向边看成两个非零元都是 $+1$ 的列，二部图把顶点分成两侧，把一侧对应的行乘以 -1，列就有了一个 $+1$ 和一个 -1，行列式只改变符号，所以二部图的关联矩阵也是全幺模的。这解释了指派问题的连续解为何能取整数，可参考卷三第 6 章“二部图匹配与指派”。

整数点的凸包 全幺模解决了一类问题，一般情形还可以这样理解。有限个点 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_k$ 的凸包是它们全部的加权平均，权重非负且和为 1。线性目标在凸包上的最小值，等于在这些点上的最小值，因为加权平均不会比最小的项更小。

所以，若能把全体整数可行点的凸包用线性不等式写出来，整数问题就成了线性规划，图 2.17(a) 就是这种幸运的情形，松弛恰好等于这个凸包。图 2.17(b) 中松弛比凸包多了一块，多出来的部分造成了整数间隙。困难在于，一般的整数问题的凸包写不出来，不等式的条数可能随规模急剧增长。

一般情形：分数顶点 图中只要出现奇圈，上面的论证就失效。考虑三个顶点的完全图（三角形），要选出尽量少的顶点，使每条边至少有一个端点被选中。这称为**顶点覆盖**（vertex cover）。用 $x_i \in \{0,1\}$ 表示是否选中顶点 i，问题是

$$\min\ x_1 + x_2 + x_3 \quad \text{s.t.} \quad x_1 + x_2 \ge 1, \quad x_2 + x_3 \ge 1, \quad x_1 + x_3 \ge 1. \tag{2.29}$$

松弛把 $x_i \in \{0,1\}$ 放宽为 $x_i \ge 0$。三条约束取等号解出的点是

$$\boldsymbol{x} = \left(\frac{1}{2}, \frac{1}{2}, \frac{1}{2}\right)^{\mathsf{T}}, \qquad \text{目标值 } \frac{3}{2}.$$

它确实是松弛的最优解。把三条约束相加，得到 $2(x_1 + x_2 + x_3) \ge 3$，这正是取权重 $(1/2, 1/2, 1/2)$ 的对偶证书，于是 $p_{\mathrm{R}} = 3/2$。

分数从哪里来？三条约束的系数矩阵是

$$\boldsymbol{E} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 0 & 1 \end{bmatrix}, \qquad \det \boldsymbol{E} = 2.$$

行列式是 2，所以不是全幺模矩阵，Cramer 法则的分母正是 2。三角形是奇圈，不能分成两侧，二部图的变号办法用不上。

整数问题的最优值是 2：只选一个顶点时，对边的两端都没被选中，这条边没有被覆盖，所以至少选两个；选两个正好够。图 2.18对比了三种取值，这个实例的整数间隙是 $2 - 3/2 = 1/2$。

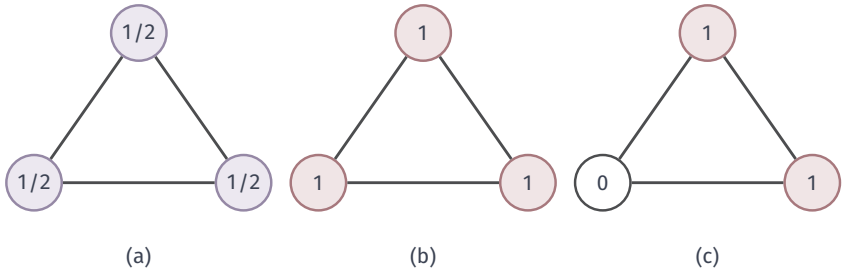


图 2.18 三角形上的顶点覆盖。圆内的数字是变量取值。(a) 松弛的最优解，三个变量都是 1/2，目标值 3/2。(b) 按阈值 1/2 舍入，三个变量都变成 1，可行，目标值 3。(c) 整数最优解之一，选两个顶点，目标值 2。

从松弛解恢复可行解 一般情形下，松弛解未必是整数，需要一个恢复步骤。恢复之后要分别回答两个问题：得到的点可行吗？目标值损失了多少？这两件事都要针对具体的约束结构来证明。前面的车间例子说明，随手舍入可能直接破坏可行性。

顶点覆盖是能够完整论证的例子。设无向图的顶点集为 V，边集为 E，顶点权重 $w_i \ge 0$。求解松弛

$$\min \sum_{i \in V} w_i x_i \quad \text{s.t.} \quad x_i + x_j \ge 1 \ (\{i,j\} \in E), \quad \boldsymbol{x} \ge \mathbf{0},$$

得到最优解 $\boldsymbol{x}^\star$，然后按阈值舍入：$x_i^\star \ge 1/2$ 时取 $\hat{x}_i = 1$，否则取 $\hat{x}_i = 0$。

定理 2.20 顶点覆盖的阈值舍入 上述 $\hat{\boldsymbol{x}}$ 是可行的顶点覆盖，并且

$$\sum_{i \in V} w_i \hat{x}_i \le 2\, p_{\mathrm{R}} \le 2\, p_{\mathrm{I}}. \tag{2.30}$$

证明 可行性：对每条边 $\{i,j\}$，$x_i^\star + x_j^\star \ge 1$，两个数中至少有一个不小于 $1/2$，相应的 $\hat{x}$ 取 1，这条边被覆盖。

目标值：按舍入规则，每个 i 都满足 $\hat{x}_i \le 2x_i^\star$。权重非负，逐项相加，得到

$$\sum_{i \in V} w_i \hat{x}_i \le 2 \sum_{i \in V} w_i x_i^\star = 2 p_{\mathrm{R}}.$$

第二个不等号是定理 2.16。 ■

三角形上这个界是 $3 \le 2 \cdot \frac{3}{2}$，等号成立，实际的最优值是 2。系数 2 不能靠这种比较再改善。在 k 个顶点的完全图上，取单位权重，把全部边的约束相加，每个顶点出现 $k-1$ 次，得到

$$(k-1) \sum_i x_i \ge \frac{k(k-1)}{2}, \qquad \text{即} \qquad \sum_i x_i \ge \frac{k}{2}.$$

全取 $1/2$ 可以达到这个下界，松弛最优值是 $k/2$。整数解至多有一个顶点不选，否则两个不选的顶点之间的边没被覆盖，所以整数最优值是 $k-1$。两者之比随 k 增大趋于 2。

这个定理的两个结论都依赖顶点覆盖的结构：可行性靠“两个数之和不小于 1”，误差靠权重非负。换一种约束，例如前面车间的问题，同样的阈值可能得到不可行的点。所以，线性松弛本身只提供界和一个出发点，恢复原问题可行解的方法要逐类设计，并单独论证可行性和误差保证。

2.1 线性规划的表述
2.2 基本可行解
2.3 线性规划的对偶
2.4 线性松弛
2.5 本章小结

松弛的界不紧或者恢复的解不够好时，还可以继续加入有效的不等式来收紧松弛，或者把问题分成子问题分别求解。这类方法都要反复求解线性规划，第 3章将说明怎样在约束增加之后，利用已有的基接着求解。

2.5 本章小结

回到章首的车间。等利润线在四边形上平移、最后停在角点，这幅图景在本章变成了三个可以计算的结论，它们的关系如图 2.19。

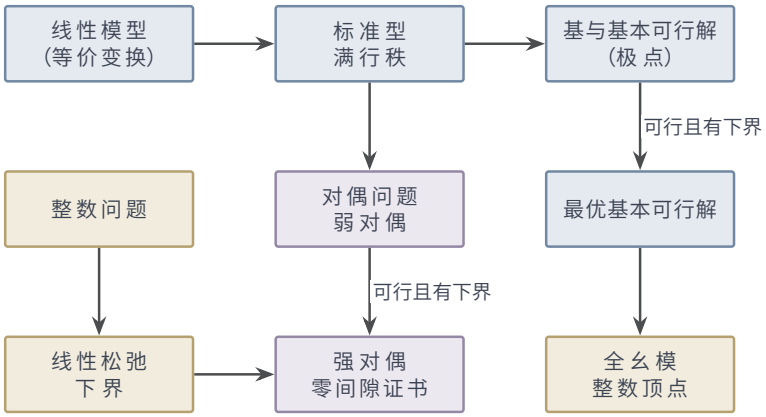


图 2.19 本章各部分的关系。蓝色框是原始问题的结构，紫色框是对偶与证书，黄色框是整数问题。箭头旁的文字是结论成立所需的条件。

第一，形式的统一。各种线性模型经过等价变换都能写成标准型，改写时松弛变量一一对应地保留可行集的形状，自由变量的分解保留最优值却可能多出角点。检查等式相容并删去冗余行之后，$\boldsymbol{A}$ 满行秩，基矩阵才有定义。

第二，解的位置。基本可行解就是可行集的极点，它由一个可逆的基矩阵解出；标准型只要可行且最优值有限，最优解就能在这有限个点中取得。非退化时换基对应沿边走到相邻顶点，退化时换基可能不移动，$\boldsymbol{u} \le \boldsymbol{0}$ 时则得到无界可行方向。这个顶点结论依赖非负约束排除直线，含直线的多面体没有极点。

第三，解的证据。给约束配权重得到对偶问题，弱对偶说明对偶间隙等于 $\boldsymbol{x}^{\mathsf{T}}\boldsymbol{s}$，因而非负，强对偶说明间隙可以精确为零。一对可行点满足互补松弛，就是最优性的完整证书，核对它只需矩阵乘法。表 2.7把这些结论和条件放在一起。

结论	所需条件
基本可行解等于极点	$\boldsymbol{A}$ 满行秩
存在最优基本可行解	标准型可行，最优值有限
沿边到不同的相邻顶点	基分量全为正，$\boldsymbol{u}$ 有正分量
弱对偶	两侧都可行
强对偶，对偶最优解存在	原始可行，最优值有限
松弛给出下界	最小化问题
顶点都是整数	$\boldsymbol{A}$ 全幺模，$\boldsymbol{b}$ 是整数

表 2.7 本章主要结论及其条件。

整数问题是另一类问题。线性松弛提供一个界；全幺模配合整数右端保证顶点是整数，网络问题属于这一类；一般情形下松弛解可能是分数，恢复可行解需要针对具体结构论证可行性和误差。

本章说明了最优解在哪里、怎样核实，但没有给出高效的求解方法。第 3章沿着基本可行解换基前进，直到拿到零间隙证书。第 4章从可行集内部出发，保持 $\boldsymbol{x}$ 和 $\boldsymbol{s}$ 为正，逐步缩小互补松弛的残差。

3.1 换基与最优性判别
3.2 初始可行基
3.3 退化的处理
3.4 修正单纯形法
3.5 对偶单纯形法
3.6 固定基的参数分析
3.7 最坏情形复杂度
3.8 本章小结

第 3 章

单纯形法

一家工厂用三种有限的资源生产两种产品，要定下各生产多少，使利润最大。第 2章说明，这类线性规划若有最优解，就有一个最优解落在可行域的顶点上，而且顶点可以用线性代数写成基本可行解。顶点的个数有限，却可能极多，逐个比较并不可行。**单纯形法**（simplex method）的做法是从一个顶点出发，每次沿一条能改善目标的边走到相邻顶点，直到手里拿到一张能证明“不必再走”的凭证。

本章用同一个工厂例子把这件事算到底。先建立一次换基怎样算、什么时候可以停；再回答第一个顶点从哪里来，遇到几条约束挤在同一个顶点时会发生什么，以及大规模问题上这些计算怎样组织。有了最优基之后，还能在资源或价格变化时复用它：对偶单纯形法从失去可行性的基接着求解，固定基的参数分析则直接读出结论成立的范围。最后一节用一族构造好的例子说明，换基的次数在最坏情形下可以随维数指数增长。

3.1 换基与最优性判别

手里已经有一个可行的顶点时，怎样判断它是不是最优；如果不是，下一步该走到哪里？

一个资源配置问题　工厂生产两种产品，产量分别记为 x_1, x_2，单位利润分别是 4 和 5。原料有 8 单位，工时有 10 单位，产品二还要占用一台专用设备，设备最多加工 3 单位。两种产品对原料和工时的消耗写在下面的约束里，于是问题是

$$\begin{aligned} \max_{x_1,x_2} \quad & 4x_1 + 5x_2 \\ \text{s.t.} \quad & x_1 + 2x_2 \le 8, \\ & 2x_1 + x_2 \le 10, \\ & x_2 \le 3, \qquad x_1, x_2 \ge 0. \end{aligned} \tag{3.1}$$

图 3.1画出它的可行域，这是一个有五个顶点的多边形。虚线是利润的等值线，沿箭头方向利润增大，最后离开多边形的那个点就是最优解。

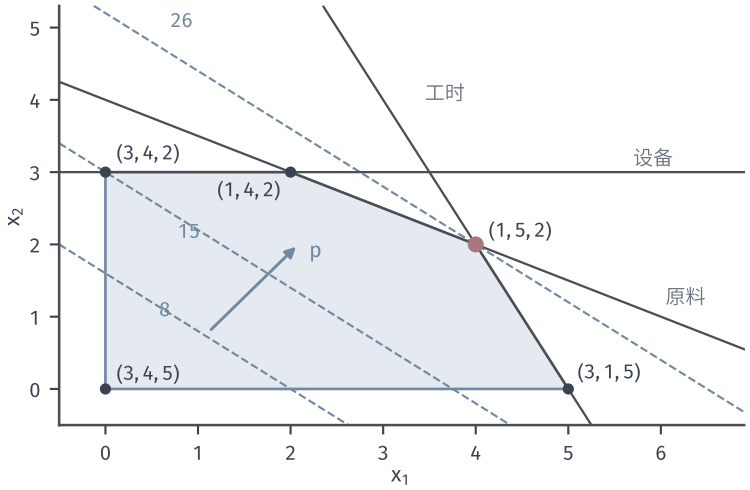


图 3.1　资源配置问题 (3.1)的可行域（浅蓝）。三条深灰线分别是原料、工时和设备约束的边界，蓝色虚线是利润 $4x_1+5x_2$ 取 $8, 15, 26$ 的等值线，箭头 $\boldsymbol{p}=(4,5)$ 指向利润增大的方向。每个顶点旁的三元组是它对应的基，红点是最优顶点 $(4,2)$。

二维时用眼睛就能找到最优点，但变量一多就画不出来，需要把“在顶点上看哪条边更好”翻译成矩阵运算。先引入松弛变量 $x_3, x_4, x_5 \ge 0$，分别表示没有用完的原料、工时和设备能力，并把最大化改写成最小化，得到第 2章的标准型

$$\min_{\boldsymbol{x}} \ \boldsymbol{c}^{\top}\boldsymbol{x} \quad \text{s.t.} \quad \boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}, \quad \boldsymbol{x}\ge \boldsymbol{0}, \tag{3.2}$$

其中 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 满行秩，第 j 列记为 $\boldsymbol{a}_j=\boldsymbol{A}_{:,j}$。本例中 $m=3$，$n=5$，数据是

$$\boldsymbol{A}=\begin{bmatrix}1&2&1&0&0\\2&1&0&1&0\\0&1&0&0&1\end{bmatrix},\quad \boldsymbol{b}=\begin{bmatrix}8\\10\\3\end{bmatrix},\quad \boldsymbol{c}=\begin{bmatrix}-4\\-5\\0\\0\\0\end{bmatrix}. \tag{3.3}$$

最小化的目标值 $f=\boldsymbol{c}^{\top}\boldsymbol{x}$ 是负的利润，所以下文中 f 越小，利润越大。

基与顶点　第 2章已经建立了下面要用的事实。取 m 个下标组成有序元组 B，使基矩阵 $\boldsymbol{A}_B$ 可逆，这样的 B 称为基，其余下标组成 N。令非基分量为零，基分量为

$$\boldsymbol{x}_B=\boldsymbol{A}_B^{-1}\boldsymbol{b},\qquad \boldsymbol{x}_N=\boldsymbol{0},$$

就得到一个基本解。$\boldsymbol{x}_B \geq \mathbf{0}$ 时它是基本可行解，也就是可行域的极点；问题可行且最优值有限时，最优解可以在基本可行解中取得。所以只需在基之间搜索。下标属于 B 的变量称为**基变量**（basic variable），其余的称为**非基变量**（nonbasic variable）。

以顶点 $(4,2)$ 为例，此时原料和工时恰好用完，即 $x_3 = x_4 = 0$，而设备还余 $x_5 = 1$。非基变量是 x_3, x_4，基变量是 x_1, x_5, x_2，我们把基写成 $B = (1,5,2)$。元组的顺序用来对应 $\boldsymbol{x}_B$ 的分量，换基时新变量占据被换出变量的位置，顺序因此保持稳定。

主要思想：用非基变量表示一切　站在一个顶点上，我们想知道沿每条边走会怎样。非基变量恰好提供了一组局部坐标：它们此刻都是零，让其中一个变大，就是离开顶点走上一条边。因此要把基变量和目标都写成非基变量的函数。

把 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 按基和非基拆开，得到 $\boldsymbol{A}_B\boldsymbol{x}_B + \boldsymbol{A}_N\boldsymbol{x}_N = \boldsymbol{b}$。两边左乘 $\boldsymbol{A}_B^{-1}$，每个满足等式约束的点都有

$$\boldsymbol{x}_B = \boldsymbol{A}_B^{-1}\boldsymbol{b} - \boldsymbol{A}_B^{-1}\boldsymbol{A}_N\boldsymbol{x}_N. \tag{3.4}$$

代入目标后，整理非基变量的系数：

$$\boldsymbol{c}^\top\boldsymbol{x} = \boldsymbol{c}_B^\top\boldsymbol{x}_B + \boldsymbol{c}_N^\top\boldsymbol{x}_N = \boldsymbol{c}_B^\top\boldsymbol{A}_B^{-1}\boldsymbol{b} + (\boldsymbol{c}_N^\top - \boldsymbol{c}_B^\top\boldsymbol{A}_B^{-1}\boldsymbol{A}_N)\boldsymbol{x}_N.$$

系数里反复出现 $\boldsymbol{c}_B^\top\boldsymbol{A}_B^{-1}$，把它单独命名。记

$$\boldsymbol{y} = \boldsymbol{A}_B^{-\top}\boldsymbol{c}_B, \qquad s_j = c_j - \boldsymbol{a}_j^\top\boldsymbol{y} \quad (j = 1, \dots, n), \tag{3.5}$$

其中 $\boldsymbol{y} \in \mathbb{R}^m$ 称为这个基的对偶候选，s_j 称为 x_j 的**约化成本**（reduced cost）。对基变量，$\boldsymbol{A}_B^\top\boldsymbol{y} = \boldsymbol{c}_B$ 正好说明 $s_j = 0$（$j \in B$）。于是每个满足等式约束的点都有

$$\boldsymbol{c}^\top\boldsymbol{x} = \boldsymbol{b}^\top\boldsymbol{y} + \sum_{j \in N} s_j x_j. \tag{3.6}$$

这个式子是本章的出发点。第一项是当前顶点的目标值，第二项说明：让非基变量 x_j 从零增加一个单位，目标改变 s_j。可以这样理解这些量：y_i 是这个基给第 i 种资源定的内部单价，$\boldsymbol{a}_j^\top\boldsymbol{y}$ 是生产一单位 x_j 所耗资源按内部单价折算的总价，s_j 是 x_j 的真实成本减去这个折算价。$s_j < 0$ 表示真实成本比折算价低，做这件事划算。

这组记号和第 2章的对偶是同一套。对偶问题要求 $\boldsymbol{A}^\top\boldsymbol{y} + \boldsymbol{s} = \boldsymbol{c}$ 且 $\boldsymbol{s} \geq \mathbf{0}$，而式 (3.5)总满足前一半，只差 $\boldsymbol{s} \geq \mathbf{0}$。“候选”二字指的就是这一点：等式已经成立，符号条件还要检查。

定理 3.1 最优性判别 设 B 是可行基，基本可行解为 $\bar{\boldsymbol{x}}$，$\boldsymbol{y}, \boldsymbol{s}$ 由式 (3.5)给出。若

$$s_j \geq 0 \quad \text{对所有} j \in N \text{成立}, \tag{3.7}$$

则 $\bar{\boldsymbol{x}}$ 是标准型 (3.2)的全局最优解，$(\boldsymbol{y}, \boldsymbol{s})$ 是对偶最优解，两者目标值相等。

证明 任取可行点 $\boldsymbol{x}$。它满足 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$，所以式 (3.6)对它成立。又因 $\boldsymbol{x}_N \geq \boldsymbol{0}$ 且 $s_j \geq 0$，右端第二项非负，于是

$$\boldsymbol{c}^{\top}\boldsymbol{x} \geq \boldsymbol{b}^{\top}\boldsymbol{y}.$$

另一方面 $\bar{\boldsymbol{x}}_N = \boldsymbol{0}$，式 (3.6)给出 $\boldsymbol{c}^{\top}\bar{\boldsymbol{x}} = \boldsymbol{b}^{\top}\boldsymbol{y}$。所以 $\bar{\boldsymbol{x}}$ 的目标值不大于任何可行点的目标值。条件 (3.7)连同基变量的 $s_j = 0$ 说明 $(\boldsymbol{y}, \boldsymbol{s})$ 对偶可行，它的对偶目标 $\boldsymbol{b}^{\top}\boldsymbol{y}$ 等于原始目标，由弱对偶知它是对偶最优解。 ■

判别只看当前顶点的约化成本，结论却是全局的，原因在于式 (3.6)对所有满足等式的点都成立，不是局部近似。约化成本全部非负，就等于对偶可行，$\boldsymbol{y}$ 就是第 2章说的下界证书。

定理的方向只有一个：非负是最优的充分条件。某个 $s_j < 0$ 时，当前顶点是否一定不是最优，要看沿这条边能否真的走出去，这正是下面要讨论的。

主要思想：沿一条边走到下一个顶点 设 $s_q < 0$，$q \in N$，我们让 x_q 增大，其余非基变量保持为零。记增大的幅度为 $\alpha \geq 0$，由式 (3.4)，基变量随之按下式变化：

$$\boldsymbol{x}_B(\alpha) = \bar{\boldsymbol{x}}_B - \alpha \boldsymbol{u}, \qquad \boldsymbol{u} = \boldsymbol{A}_B^{-1}\boldsymbol{a}_q. \tag{3.8}$$

$\boldsymbol{u}$ 的含义很具体：u_i 是 x_q 每增加一单位时，位于第 i 个位置的基变量要减少的量。用整个向量来写，移动方向 $\boldsymbol{d} \in \mathbb{R}^n$ 满足 $d_q = 1$，$\boldsymbol{d}_B = -\boldsymbol{u}$，其余分量为零。

沿这个方向走，等式约束不被破坏，目标按 s_q 下降。两件事都可以直接验算：

$$\boldsymbol{A}\boldsymbol{d} = \boldsymbol{a}_q - \boldsymbol{A}_B\boldsymbol{u} = \boldsymbol{0}, \qquad \boldsymbol{c}^{\top}\boldsymbol{d} = c_q - \boldsymbol{c}_B^{\top}\boldsymbol{A}_B^{-1}\boldsymbol{a}_q = s_q.$$

图 3.2在顶点 $(2,3)$ 上画出了这两种可能。这个顶点的基是 $(1,4,2)$，x_3, x_5 非基。让 x_3 增大，点沿设备约束的边向左移动，目标以速率 $s_3 = 4$ 变差；让 x_5 增大，点沿原料约束的边向右下移动，目标以速率 $s_5 = -3$ 变好。

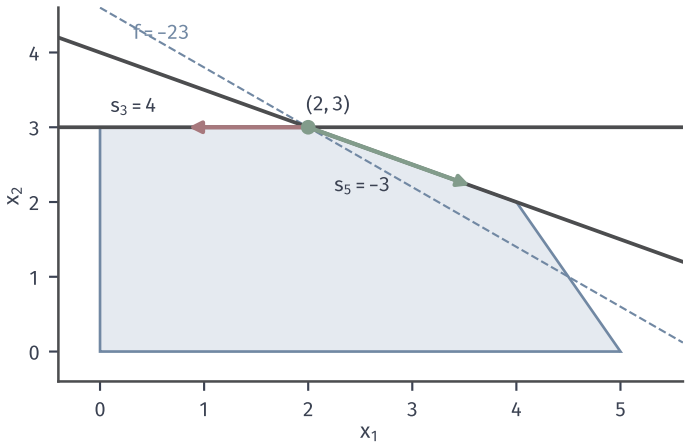


图 3.2　顶点 $(2,3)$ 处的两条边。深灰粗线是在此活动的设备和原料约束，蓝色虚线是过该点的等值线 $f = -23$。红色箭头是 x_3 增大的方向，走上去 f 每单位增加 4；绿色箭头是 x_5 增大的方向，走上去 f 每单位减少 3，它越过等值线进入利润更高的一侧。

能走多远由基变量的非负性决定。$u_i \le 0$ 的基变量不会减小，不构成限制；$u_i > 0$ 的基变量在 $\alpha = \bar{x}_{B(i)}/u_i$ 时降到零，其中 $B(i)$ 是基中第 i 个下标。最先降到零的那个变量决定步长：

$$\alpha^\star = \min_{i:\, u_i > 0} \frac{\bar{x}_{B(i)}}{u_i}. \tag{3.9}$$

这称为**比值检验**（ratio test）。像预算线一样，每种资源各自算出“还够做多少”，能做的量由最紧的那一种决定。图 3.3把基变量画成 α 的直线，第一条碰到零的直线给出步长。

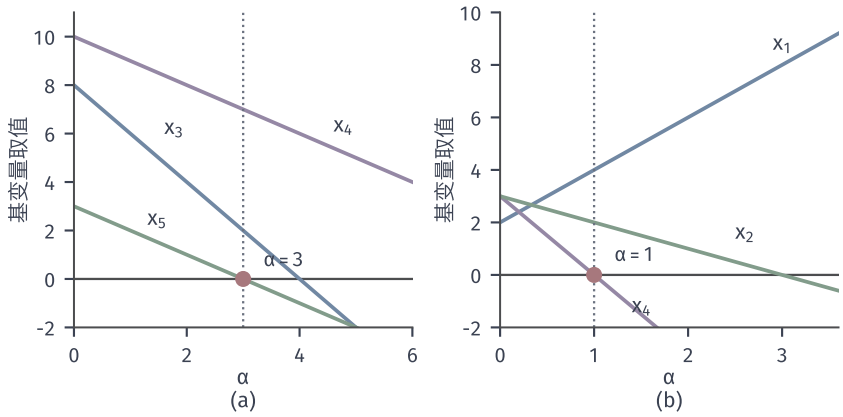


图 3.3 比值检验的两个实例，三条直线是基变量随步长 α 的变化，红点是最先降到零的位置。(a) 入基变量 x_2，基 $(3,4,5)$，x_5 先到零，$\alpha^\star = 3$。(b) 入基变量 x_5，基 $(1,4,2)$，x_1 随 α 增大而增大，不起限制作用，x_4 先到零，$\alpha^\star = 1$。

设最小值在位置 r 取到，$p = B(r)$。走到 $\alpha^\star$ 后 $x_p = 0$，$x_q = \alpha^\star$，于是把 p 从基中换出、q 换入。x_q 称为**入基变量**（entering variable），x_p 称为**出基变量**（leaving variable），这一次替换称为**换基**（pivot）。下面的引理保证替换后仍是一个可行基。

引理 3.2　换基的合法性　设 $s_q < 0$，$\boldsymbol{u}$ 由式 (3.8)给出且 $\boldsymbol{u}$ 至少有一个正分量，r 在式 (3.9)中取到最小值。把 B 的第 r 个下标换成 q，得到的 B' 仍是基，$\bar{\boldsymbol{x}} + \alpha^\star \boldsymbol{d}$ 是它的基本可行解，目标值为

$$\boldsymbol{c}^\top \bar{\boldsymbol{x}} + \alpha^\star s_q. \tag{3.10}$$

证明　先证 $\boldsymbol{A}_{B'}$ 可逆。由 $\boldsymbol{A}_B \boldsymbol{u} = \boldsymbol{a}_q$，有 $\boldsymbol{a}_q = \sum_i u_i \boldsymbol{a}_{B(i)}$，其中 $\boldsymbol{a}_{B(r)}$ 的系数 $u_r > 0$。若 $\boldsymbol{A}_{B'}$ 的列线性相关，由于其余 $m-1$ 列线性无关，$\boldsymbol{a}_q$ 就能只用这 $m-1$ 列表示，这与 $\boldsymbol{a}_q$ 在基 $\boldsymbol{A}_B$ 下表示的唯一性及 $u_r \neq 0$ 矛盾。

再看新点。由 $\boldsymbol{A}\boldsymbol{d} = \boldsymbol{0}$，等式约束保持成立。$\alpha^\star$ 的取法使所有基变量非负，$x_q = \alpha^\star \geq 0$。新点在位置 p 和 $N \setminus \{q\}$ 上的分量都是零，也就是 B' 之外的分量都是零，所以它是 B' 的基本可行解。目标值由 $\boldsymbol{c}^\top \boldsymbol{d} = s_q$ 得到。 ■

$\alpha^\star > 0$ 时，目标严格下降，点从一个顶点沿边走到了相邻顶点。这就是单纯形法的全部几何内容。

变量　下面用工厂的例子走完整个过程。计算中出现的量及其形状如下。

- $B^{(t)}$：第 t 轮的基，含 m 个下标的有序元组；$N^{(t)}$ 是其余 $n-m$ 个下标。
- $\boldsymbol{x}_B^{(t)} \in \mathbb{R}^m$：基变量的取值，非基变量都是零。
- $\boldsymbol{y}^{(t)} \in \mathbb{R}^m$：对偶候选。
- $s_j^{(t)}$：非基变量的约化成本。
- $q^{(t)}$：入基下标；$\boldsymbol{u}^{(t)} \in \mathbb{R}^m$：入基列在当前基下的表示。
- $\alpha^{(t)} \ge 0$：步长；$r^{(t)}$：出基位置，$p^{(t)} = B^{(t)}(r^{(t)})$ 是出基下标。

初始化　需要一个可行基 $B^{(0)}$。当 $\boldsymbol{b} \ge \boldsymbol{0}$ 且每个约束都带松弛变量时，取全部松弛变量为基即可，此时 $\boldsymbol{A}_B = \boldsymbol{I}$。其他情形在第 3.2节处理。例中

$$B^{(0)} = (3,4,5), \qquad \boldsymbol{A}_{B^{(0)}} = \boldsymbol{I}, \qquad \boldsymbol{x}_B^{(0)} = \begin{bmatrix} 8 \\ 10 \\ 3 \end{bmatrix}.$$

对应顶点 $(0,0)$，什么都不生产，$f = 0$。

每轮更新　第 t 轮依次做下面几步。步骤后的“例中”是第 0 轮的数据，其余各轮随后列出。

1. 计算对偶候选。由式 (3.5),

$$\boldsymbol{y}^{(t)} = \left(\boldsymbol{A}_{B^{(t)}}\right)^{-\mathsf{T}} \boldsymbol{c}_{B^{(t)}}.$$

   例中 $\boldsymbol{c}_B = \boldsymbol{0}$，所以

$$\boldsymbol{y}^{(0)} = (0,0,0)^{\mathsf{T}}.$$

2. 定价，即对每个非基下标计算约化成本 $s_j^{(t)} = c_j - \boldsymbol{a}_j^{\mathsf{T}} \boldsymbol{y}^{(t)}$。例中

$$s_1^{(0)} = -4, \qquad s_2^{(0)} = -5.$$

3. 判别。若所有 $s_j^{(t)} \ge 0$，停止，当前解最优。否则选一个 $s_q^{(t)} < 0$ 的下标 $q = q^{(t)}$ 入基。本节取约化成本最负的下标, 称为Dantzig 规则（Dantzig's rule），并列时取下标最小者。例中 s_2 最负，所以

$$q^{(0)} = 2.$$

4. 计算入基列的表示。由式 (3.8),

$$\boldsymbol{u}^{(t)} = \left(\boldsymbol{A}_{B^{(t)}}\right)^{-1} \boldsymbol{a}_q.$$

若 $\boldsymbol{u}^{(t)} \le \mathbf{0}$，停止，问题无界。例中

$$\boldsymbol{u}^{(0)} = \boldsymbol{a}_2 = (2,1,1)^{\top}.$$

5. 比值检验。由式 (3.9)求 $\alpha^{(t)}$ 和出基位置 $r^{(t)}$，并列时本节取下标最小的基变量。例中三个比值是

$$\frac{x_3}{u_1} = \frac{8}{2} = 4, \qquad \frac{x_4}{u_2} = \frac{10}{1} = 10, \qquad \frac{x_5}{u_3} = \frac{3}{1} = 3,$$

所以

$$\alpha^{(0)} = 3, \qquad r^{(0)} = 3, \qquad p^{(0)} = 5.$$

6. 更新基和基变量。除第 r 个位置外，

$$\boldsymbol{x}_B^{(t+1)} = \boldsymbol{x}_B^{(t)} - \alpha^{(t)} \boldsymbol{u}^{(t)}, \tag{3.11}$$

第 r 个位置改放 $x_q = \alpha^{(t)}$，并把 $B^{(t)}$ 的第 r 个下标换成 q。例中

$$B^{(1)} = (3,4,2), \qquad \boldsymbol{x}_B^{(1)} = \begin{bmatrix} 8 - 3\cdot 2 \\ 10 - 3\cdot 1 \\ 3 \end{bmatrix} = \begin{bmatrix} 2 \\ 7 \\ 3 \end{bmatrix}.$$

目标值由式 (3.10)变为 $0 + 3\cdot(-5) = -15$，点走到 $(0,3)$。

例中第 1 轮的基矩阵是

$$\boldsymbol{A}_{B^{(1)}} = \begin{bmatrix} 1 & 0 & 2 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix}.$$

解 $\boldsymbol{A}_B^{\top}\boldsymbol{y} = \boldsymbol{c}_B$，其中 $\boldsymbol{c}_B = (0,0,-5)^{\top}$，再计算两个非基变量的约化成本：

$$\boldsymbol{y}^{(1)} = (0,0,-5)^{\top}, \qquad s_1^{(1)} = -4, \qquad s_5^{(1)} = 5.$$

只有 $s_1 < 0$，所以 x_1 入基。它的表示和两个有效比值为

$$\boldsymbol{u}^{(1)} = (1,2,0)^{\top}, \qquad \frac{x_3}{u_1} = \frac{2}{1} = 2, \qquad \frac{x_4}{u_2} = \frac{7}{2}.$$

第三个分量 $u_3 = 0$，产品一不占专用设备，x_2 不受影响。于是 $\alpha^{(1)} = 2$，x_3 出基，更新后

$$B^{(2)} = (1,4,2), \qquad \boldsymbol{x}_B^{(2)} = \begin{bmatrix} 2 \\ 7 - 2\cdot 2 \\ 3 \end{bmatrix} = \begin{bmatrix} 2 \\ 3 \\ 3 \end{bmatrix}.$$

目标值变为 $-15+2\cdot(-4)=-23$，点走到 $(2,3)$。

例中第 2 轮的基矩阵和对偶候选是

$$\boldsymbol{A}_{B^{(2)}}=\begin{bmatrix}1&0&2\\2&1&1\\0&0&1\end{bmatrix},\qquad \boldsymbol{c}_B=\begin{bmatrix}-4\\0\\-5\end{bmatrix},\qquad \boldsymbol{y}^{(2)}=\begin{bmatrix}-4\\0\\3\end{bmatrix}.$$

非基变量 x_3,x_5 的约化成本为

$$s_3^{(2)}=0-(-4)=4,\qquad s_5^{(2)}=0-3=-3.$$

这里出现了一个值得留意的现象：x_5 是设备的余量，让它入基意味着故意不用满设备。$s_5<0$ 说明把设备让出一些，腾出的原料拿去做产品一更赚钱。x_5 入基，表示向量和比值为

$$\boldsymbol{u}^{(2)}=(-2,3,1)^{\top},\qquad \frac{x_4}{u_2}=\frac{3}{3}=1,\qquad \frac{x_2}{u_3}=\frac{3}{1}=3.$$

$u_1=-2<0$ 表示 x_1 会增大，不参与比较。于是 $\alpha^{(2)}=1$，x_4 出基，按式 (3.11)更新：

$$B^{(3)}=(1,5,2),\qquad \boldsymbol{x}_B^{(3)}=\begin{bmatrix}2+2\\1\\3-1\end{bmatrix}=\begin{bmatrix}4\\1\\2\end{bmatrix}.$$

目标值变为 $-23+1\cdot(-3)=-26$，点走到 $(4,2)$。

例中第 3 轮的基矩阵和对偶候选是

$$\boldsymbol{A}_{B^{(3)}}=\begin{bmatrix}1&0&2\\2&0&1\\0&1&1\end{bmatrix},\qquad \boldsymbol{c}_B=\begin{bmatrix}-4\\0\\-5\end{bmatrix},\qquad \boldsymbol{y}^{(3)}=\begin{bmatrix}-2\\-1\\0\end{bmatrix}.$$

非基变量 x_3,x_4 的约化成本为

$$s_3^{(3)}=0-(-2)=2,\qquad s_4^{(3)}=0-(-1)=1.$$

两者都非负，算法停止。表 3.1汇总了四轮的数据。

t	$B^{(t)}$	(x_1, x_2)	f	$\boldsymbol{y}^{(t)}$	入基／出基
0	$(3,4,5)$	$(0,0)$	0	$(0,0,0)$	x_2 ／ x_5
1	$(3,4,2)$	$(0,3)$	-15	$(0,0,-5)$	x_1 ／ x_3
2	$(1,4,2)$	$(2,3)$	-23	$(-4,0,3)$	x_5 ／ x_4
3	$(1,5,2)$	$(4,2)$	-26	$(-2,-1,0)$	停止

表 3.1　资源配置问题在 Dantzig 规则下的各轮数据。

最终得到　算法结束时得到最优基 $B^\star = (1,5,2)$ 和最优解

$$\boldsymbol{x}^\star = (4,2,0,0,1)^\top, \qquad p^\star = -26, \tag{3.12}$$

即产品一做 4、产品二做 2，利润 26，原料和工时用完，设备余 1。同时得到对偶最优解

$$\boldsymbol{y}^\star = (-2,-1,0)^\top, \qquad \boldsymbol{s}^\star = (0,0,2,1,0)^\top. \tag{3.13}$$

证书可以当场核对：一方面 $\boldsymbol{b}^\top \boldsymbol{y}^\star = -16 - 10 = -26 = p^\star$，另一方面 $(\boldsymbol{x}^\star)^\top \boldsymbol{s}^\star = 0$，互补松弛成立。

几何上，最优性说的是目标方向落在活动约束法向量张成的锥里。把最大化写回去，利润向量恰好是原料和工时两个法向量的非负组合：

$$\begin{bmatrix} 4 \\ 5 \end{bmatrix} = 2\begin{bmatrix} 1 \\ 2 \end{bmatrix} + 1\begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

图 3.4画的就是这个分解，组合系数 $2, 1$ 正是 $-\boldsymbol{y}^\star$ 的前两个分量。

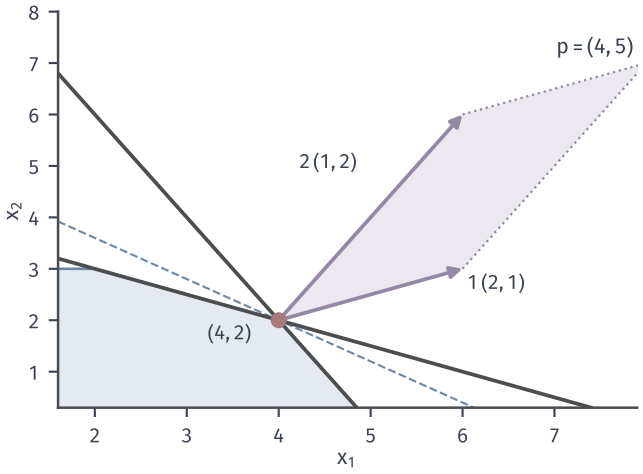


图 3.4　最优顶点 $(4,2)$ 处的对偶证书。深灰粗线是两条活动约束，紫色箭头是它们的法向量按系数 2 和 1 缩放后的结果，蓝色箭头是利润向量 $\boldsymbol{p}$，它是紫色平行四边形的对角线，因此落在两个法向量张成的锥内。蓝色虚线是过该点的等值线。

换基规则影响路径，不影响结论 Dantzig 规则只看单位变化率，不看能走多远。图 3.5对比了同一问题上的两条路径：Dantzig 规则先选利润系数大的 x_2，走了三步；若总选下标最小的负约化成本，则先选 x_1，经 $(5,0)$ 两步到达。两条路径终点相同，因为最优性判别不依赖路径。这个例子不能说明后一种规则更好，它只说明步数取决于规则与问题的搭配。

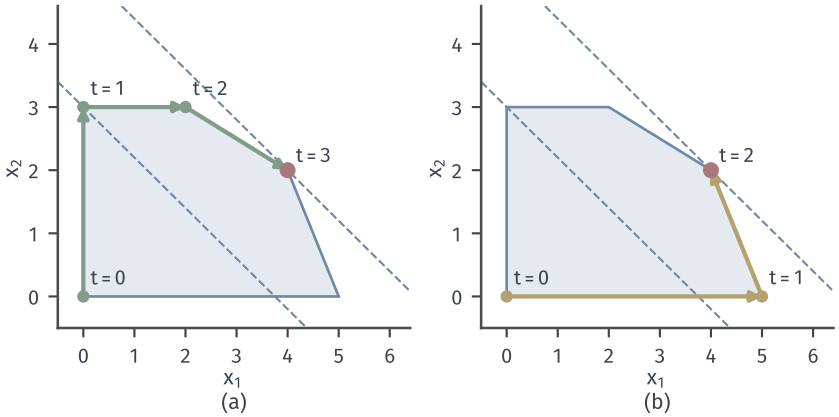


图 3.5 同一问题上的两条换基路径，蓝色虚线是利润 15 和 26 的等值线，红点是最优解。(a) Dantzig 规则（绿色），经 $(0,3)$ 和 $(2,3)$ 共三次换基。(b) 总选下标最小的负约化成本（黄色），经 $(5,0)$ 共两次换基。

没有出基变量：无界证书 比值检验可能找不到任何限制。此时 $\boldsymbol{u} \le \mathbf{0}$，对一切 $\alpha \ge 0$，$\bar{\boldsymbol{x}} + \alpha \boldsymbol{d}$ 都可行，目标按 αs_q 趋于 $-\infty$。这个 $\bar{\boldsymbol{x}}$ 和 $\boldsymbol{d}$ 合在一起就是问题无下界的证据：

$$\boldsymbol{A}\boldsymbol{d} = \mathbf{0}, \qquad \boldsymbol{d} \ge \mathbf{0}, \qquad \boldsymbol{c}^{\top}\boldsymbol{d} = s_q < 0. \tag{3.14}$$

示例 3.3 无界问题 考虑最大化 $x_1 + x_2$，约束为 $x_1 - x_2 \le 2$，$-x_1 + x_2 \le 1$，$x_1, x_2 \ge 0$。加松弛变量 x_3, x_4，从 $B = (3,4)$ 出发，约化成本是 $s_1 = s_2 = -1$，取 x_1 入基。比值检验给出 x_3 出基，$\alpha = 2$，点到达 $(2,0)$。

第二轮 $B = (1,4)$，对偶候选和约化成本为

$$\boldsymbol{y} = (-1,0)^{\top}, \qquad s_2 = -2, \qquad s_3 = 1.$$

x_2 入基，它的表示是

$$\boldsymbol{u} = (-1,0)^{\top} \le \mathbf{0}.$$

没有基变量会减小，比值检验无从进行。按式 (3.14)得到无界方向 $\boldsymbol{d} = (1,1,0,0)^{\top}$，沿它每走一单位，目标减少 2。

3.1 换基与最优性判别
3.2 初始可行基
3.2.1 两阶段法
3.2.2 大 M 法
3.3 退化的处理
3.4 修正单纯形法
3.5 对偶单纯形法
3.6 固定基的参数分析
3.7 最坏情形复杂度
3.8 本章小结

图 3.6中可行域是一条向右上方延伸的带子，红色射线在带子里一直走不出去，而利润不断增大。

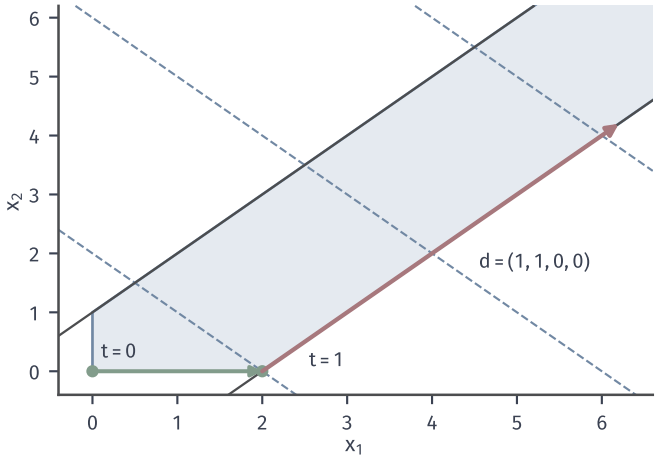


图 3.6　例 3.3的无界可行域（浅蓝，向右上方无限延伸）。绿色是一次换基，从 $(0,0)$ 到 $(2,0)$；红色射线是无界方向 $\boldsymbol{d}$，蓝色虚线是利润 $2, 6, 10$ 的等值线，射线不断穿过利润更高的等值线。

走不动的换基　还有一种情形需要先记下来。若某个基变量已经是零，且它对应的 $u_i > 0$，式 (3.9)给出 $\alpha^\star = 0$。这时基换了，点没动，目标也没变，这样的基是退化基。所以 $s_q < 0$ 只说明这条边的方向改善目标，并不保证真能走出去，$\alpha^\star = 0$ 时当前点可能已经最优。第 3.3节专门处理这种情形。

没有退化时，算法的终止性可以直接得出。

定理 3.4　非退化时的有限终止　设算法访问的每个基都非退化，则从任一可行基出发，单纯形法经过有限次换基后，或得到满足式 (3.7)的最优基，或得到满足式 (3.14)的无界方向。

证明　非退化时 $\boldsymbol{x}_B > \boldsymbol{0}$，比值检验给出 $\alpha^\star > 0$，由式 (3.10)，目标严格下降，所以任何基都不会重复访问。基的个数不超过从 n 个下标中选 m 个的组合数，是有限的，因此换基只能进行有限次。算法每轮要么换基，要么在两种停止条件之一下结束，由此得到结论。 ■

3.2 初始可行基

上一节的算法要从一个可行基出发，而工厂例子里松弛变量恰好提供了一个。本节解决没有现成可行基时怎么办。

3.1 换基与最优性判别
3.2 初始可行基
3.2.1 两阶段法
3.2.2 大 M 法
3.3 退化的处理
3.4 修正单纯形法
3.5 对偶单纯形法
3.6 固定基的参数分析
3.7 最坏情形复杂度
3.8 本章小结

给工厂加一个合同要求：两种产品合计至少交付 2 单位，即 $x_1 + x_2 \geq 2$。这个不等式要减去一个非负的剩余变量 x_6 才能化成等式，标准型的第四行是

$$x_1 + x_2 - x_6 = 2. \tag{3.15}$$

若仍取松弛变量和剩余变量组成基，第四行给出 $x_6 = -2 < 0$，不可行。这对应图 3.7中的原点：什么都不生产，合同就违约了，原点已不在可行域内。等式约束的情形更直接，它没有松弛变量可用。

人工变量 解决办法是暂时允许约束被违反，并给违反量记账。把各行乘以适当的符号使 $\boldsymbol{b} \geq \boldsymbol{0}$，对缺少现成基列的行，引入非负的**人工变量**（artificial variable）$\boldsymbol{v}$，得到扩大的约束

$$\boldsymbol{A}\boldsymbol{x} + \boldsymbol{v} = \boldsymbol{b}, \qquad \boldsymbol{x} \geq \boldsymbol{0}, \quad \boldsymbol{v} \geq \boldsymbol{0}. \tag{3.16}$$

为叙述简单，这里写成每行都加人工变量；已有松弛变量可作基列的行不必加，例中只有第四行需要。

这个系统立刻有可行基：$\boldsymbol{x} = \boldsymbol{0}$，$\boldsymbol{v} = \boldsymbol{b}$。但要分清，它是扩大问题的可行基，不是原问题的：只要某个 $v_i > 0$，对应的原约束就没有被满足。$\boldsymbol{v}$ 像一笔临时垫付的账，只有全部还清，得到的点才是原问题的可行点。

例中把人工变量记作 x_7，扩大后的约束有四行七列：

$$\begin{bmatrix} 1 & 2 & 1 & 0 & 0 & 0 & 0 \\ 2 & 1 & 0 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & -1 & 1 \end{bmatrix} \boldsymbol{x} = \begin{bmatrix} 8 \\ 10 \\ 3 \\ 2 \end{bmatrix}.$$

起始基 $(3, 4, 5, 7)$ 的基矩阵是单位矩阵，$x_7 = 2$ 就是合同的缺口。两阶段法和大 M 法用两种方式把这笔账还清。

3.2.1 两阶段法

主要思想 两阶段法（two-phase method）把“还清账”和“优化目标”分开。第一阶段暂时不管原目标，只最小化人工变量之和：

$$\min_{\boldsymbol{x},\boldsymbol{v}} \ \phi = \boldsymbol{1}^{\top}\boldsymbol{v} \quad \text{s.t.} \quad \boldsymbol{A}\boldsymbol{x} + \boldsymbol{v} = \boldsymbol{b}, \quad \boldsymbol{x} \geq \boldsymbol{0}, \quad \boldsymbol{v} \geq \boldsymbol{0}. \tag{3.17}$$

这个问题有现成的可行基，目标又以 0 为下界，所以单纯形法不会遇到无界，一定有最优值 $\phi^{\star} \geq 0$。它回答了可行性问题。

定理 3.5 第一阶段的结论 原问题 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$，$\boldsymbol{x}\ge\boldsymbol{0}$ 可行，当且仅当问题 (3.17)的最优值 $\phi^\star=0$。若 $\phi^\star>0$，设 $\boldsymbol{y}$ 是第一阶段最优基的对偶候选，则

$$\boldsymbol{A}^\top\boldsymbol{y}\le\boldsymbol{0},\qquad \boldsymbol{b}^\top\boldsymbol{y}=\phi^\star>0, \tag{3.18}$$

这个 $\boldsymbol{y}$ 就是原问题不可行的证书。

证明 若原问题有可行点 $\boldsymbol{x}$，则 $(\boldsymbol{x},\boldsymbol{0})$ 对问题 (3.17)可行，目标为零，又因 $\phi\ge0$，所以 $\phi^\star=0$。反过来，$\phi^\star=0$ 时最优解满足 $\boldsymbol{v}=\boldsymbol{0}$，它的 $\boldsymbol{x}$ 部分满足 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$，$\boldsymbol{x}\ge\boldsymbol{0}$。

设 $\phi^\star>0$。第一阶段的目标系数在 $\boldsymbol{x}$ 上是零，于是最优性条件 $s_j=0-\boldsymbol{a}_j^\top\boldsymbol{y}\ge0$ 说明 $\boldsymbol{A}^\top\boldsymbol{y}\le\boldsymbol{0}$。由定理 3.1，两边目标值相等，即 $\boldsymbol{b}^\top\boldsymbol{y}=\phi^\star$。若存在 $\boldsymbol{x}\ge\boldsymbol{0}$ 满足 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$，就有

$$0<\boldsymbol{b}^\top\boldsymbol{y}=\boldsymbol{x}^\top\boldsymbol{A}^\top\boldsymbol{y}\le0,$$

矛盾，这说明 $\boldsymbol{y}$ 确实证明了不可行。 ■

变量 第一阶段沿用第 3.1节的全部变量，只是下标范围包括人工变量，目标向量换成在 $\boldsymbol{x}$ 上为零、在 $\boldsymbol{v}$ 上为一的 $\boldsymbol{g}$。第二阶段回到原来的 $\boldsymbol{c}$，并去掉人工变量对应的列。

初始化 第一阶段从人工变量和可用的松弛变量组成的基出发。例中

$$B^{(0)}=(3,4,5,7),\qquad \boldsymbol{x}_B^{(0)}=(8,10,3,2)^\top,\qquad \phi=2.$$

每轮更新 两个阶段的每轮计算都与第 3.1节相同，区别只在目标向量和两阶段之间的衔接。

1. 第一阶段按 $\boldsymbol{g}$ 运行单纯形法，直到约化成本全部非负。例中第 0 轮的对偶候选和约化成本为

$$\boldsymbol{y}^{(0)}=(0,0,0,1)^\top,\qquad s_1=-1,\quad s_2=-1,\quad s_6=1.$$

s_1,s_2 并列最负，取下标小的 x_1 入基。它的表示和比值为

$$\boldsymbol{u}^{(0)}=(1,2,0,1)^\top,\qquad \frac{8}{1}=8,\quad \frac{10}{2}=5,\quad \frac{2}{1}=2.$$

于是 $\alpha^{(0)}=2$，x_7 出基，更新后

$$B^{(1)}=(3,4,5,1),\qquad \boldsymbol{x}_B^{(1)}=(6,6,3,2)^\top,\qquad \phi=0.$$

第 1 轮人工变量已经出基，$\boldsymbol{y}^{(1)}=\mathbf{0}$，所有 $s_j\ge 0$，第一阶段结束，得到 $\phi^\star=0$ 和原问题的顶点 $(2,0)$。

2. 判断 $\phi^\star$。若 $\phi^\star>0$，按定理 3.5报告不可行并给出 $\boldsymbol{y}$。例中 $\phi^\star=0$，继续。

3. 处理仍在基中的人工变量（做法见下文）。例中人工变量已经出基，无需处理。

4. 第二阶段用基 $B^{(1)}$ 和原目标 $\boldsymbol{c}$ 继续运行单纯形法。例中三轮的数据如下。

第二阶段第 0 轮，基是 $(3,4,5,1)$，$f=-8$。对偶候选和约化成本是

$$\boldsymbol{y}=(0,0,0,-4)^{\top},\qquad s_2=-1,\qquad s_6=-4.$$

s_6 最负，x_6 入基，意味着多交付一些。表示向量和有效比值是

$$\boldsymbol{u}=(1,2,0,-1)^{\top},\qquad \frac{6}{1}=6,\qquad \frac{6}{2}=3.$$

于是 $\alpha=3$，x_4 出基，更新后

$$B=(3,6,5,1),\qquad \boldsymbol{x}_B=(3,3,3,5)^{\top},\qquad f=-20.$$

第二阶段第 1 轮，点在 $(5,0)$。对偶候选和约化成本是

$$\boldsymbol{y}=(0,-2,0,0)^{\top},\qquad s_2=-3,\qquad s_4=2.$$

x_2 入基。表示向量和三个有效比值是

$$\boldsymbol{u}=\Big(\frac{3}{2},-\frac{1}{2},1,\frac{1}{2}\Big)^{\top},\qquad \frac{3}{3/2}=2,\quad \frac{3}{1}=3,\quad \frac{5}{1/2}=10.$$

于是 $\alpha=2$，x_3 出基，更新后

$$B=(2,6,5,1),\qquad \boldsymbol{x}_B=(2,4,1,4)^{\top},\qquad f=-26.$$

第二阶段第 2 轮，对偶候选和约化成本是

$$\boldsymbol{y}=(-2,-1,0,0)^{\top},\qquad s_3=2,\qquad s_4=1.$$

全部非负，算法停止。

最终得到　最优解仍是 $(x_1,x_2)=(4,2)$，$p^\star=-26$，此时 $x_6=4$ 表示比合同多交付了 4。合同约束在最优点不活动，对偶分量 $y_4=0$，加上它并不改变答案。图 3.7画出了两个阶段的路径。

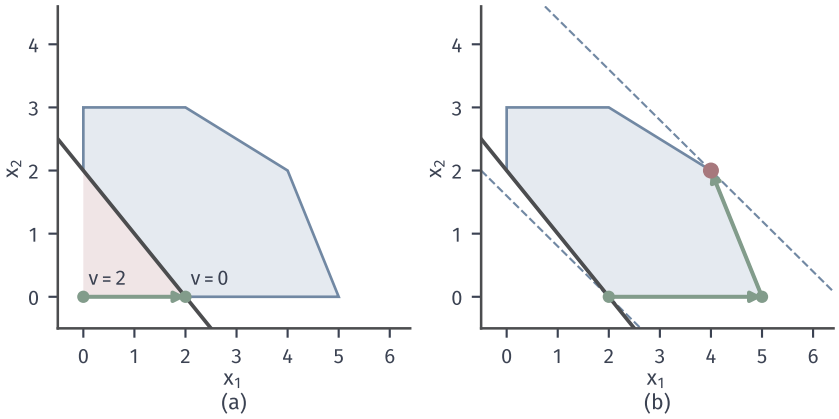


图 3.7 两阶段法的路径。深灰粗线是合同约束 $x_1 + x_2 = 2$，浅蓝是原问题的可行域，它不含原点。(a) 第一阶段：从不可行的原点出发（红色浅底是违约区），沿 x_1 轴走到人工变量 $v = x_7$ 降为零的点。(b) 第二阶段：从 $(2,0)$ 出发，用原目标走到红色的最优点，蓝色虚线是利润 8 和 26 的等值线。

第一阶段判定不可行 把合同改成 $x_1 + x_2 \geq 7$。第一阶段从 $\phi = 7$ 开始，三轮的基和人工变量值为

$$
\begin{aligned}
B^{(0)} &= (3,4,5,7), \quad x_7 = 7,\\
B^{(1)} &= (3,1,5,7), \quad x_7 = 2,\\
B^{(2)} &= (2,1,5,7), \quad x_7 = 1.
\end{aligned}
$$

第 2 轮的对偶候选和约化成本是

$$
\boldsymbol{y} = \left(-\frac{1}{3}, -\frac{1}{3}, 0, 1\right)^{\top}, \qquad s_3 = \frac{1}{3}, \quad s_4 = \frac{1}{3}, \quad s_6 = 1.
$$

全部非负而 $\phi^\star = 1 > 0$，原问题不可行。

证书 $\boldsymbol{y}$ 可以翻译成一句平常的话。原料和工时两个约束各乘 $\frac{1}{3}$ 相加，得到 $x_1 + x_2 \leq 6$，这与 $x_1 + x_2 \geq 7$ 矛盾，差额正好是 $\phi^\star = 1$。图 3.8中，第一阶段把点推到离合同线最近的顶点，停在那里，仍差 1。

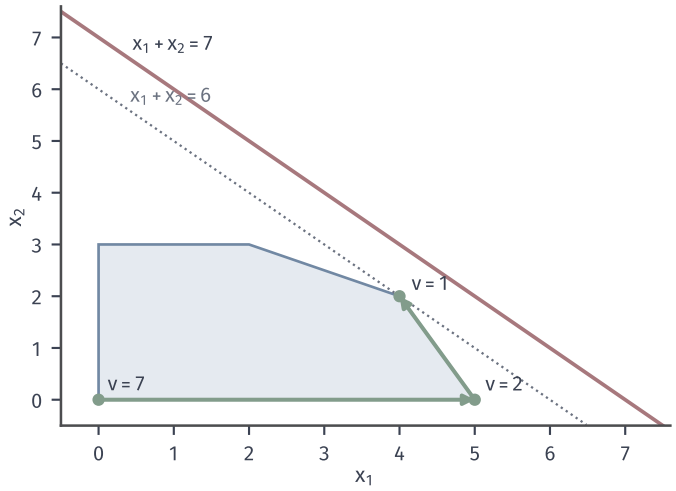


图 3.8 合同要求提高到 $x_1 + x_2 \geq 7$ 时的第一阶段。红线是合同边界，点线 $x_1 + x_2 = 6$ 是资源约束组合出的上限，两者之间没有可行点。绿色路径沿资源多边形的边界推进，人工变量 v 依次取 $7, 2, 1$，在第一阶段最优点停在 $v = 1$。

基中残留的人工变量 $\phi^\star = 0$ 时，人工变量的值全为零，但可能有个别人工变量仍在基中，取值为零。第二阶段不能直接开始，否则人工变量可能在后续换基中重新变正。设它位于基的第 r 个位置，定义该行的系数

$$\boldsymbol{\rho} = \boldsymbol{A}_B^{-\top} \boldsymbol{e}_r, \qquad \bar{a}_{r,j} = \boldsymbol{\rho}^\top \boldsymbol{a}_j, \tag{3.19}$$

其中 $\boldsymbol{e}_r$ 是第 r 个坐标向量，$\bar{a}_{r,j}$ 就是把 $\boldsymbol{a}_j$ 用基表示时第 r 个分量。分两种情况处理。

- 存在原变量 x_j（$j \in N$）使 $\bar{a}_{r,j} \neq 0$。把 x_j 换入第 r 个位置。由于该位置的值是零，步长为零，其他变量不变，符号不必为正。
- 对所有原变量都有 $\bar{a}_{r,j} = 0$。此时 $\boldsymbol{\rho}^\top \boldsymbol{A} = \boldsymbol{0}^\top$，$\boldsymbol{\rho} \neq \boldsymbol{0}$，说明这一行是其余行的线性组合，是冗余等式，可以连同该人工变量一起删去。

第二种情况也说明，第 2章假定 $\boldsymbol{A}$ 满行秩并不需要预先检查，第一阶段顺带就发现了冗余行。下面的例子展示两种情况。

示例 3.6 换出与删行 考虑约束 $x_1 + x_2 + x_3 = 2, 2x_1 + \omega(x_2 + x_3) = 4$，$\boldsymbol{x} \geq \boldsymbol{0}$，其中 ω 取 1 或 2，人工变量是 x_4, x_5。从基 $(4, 5)$ 出发，x_1 的约化成本最负。比值都是 2，并列时取下标小的 x_4 出基，得到基 $(1, 5)$ 和

$$\boldsymbol{x}_B = (2, 0)^\top, \qquad \phi = 0, \qquad \boldsymbol{\rho} = (-2, 1)^\top.$$

x_5 在基中取零。

3.1 换基与最优性判别
3.2 初始可行基
3.2.1 两阶段法
3.2.2 大 M 法
3.3 退化的处理
3.4 修正单纯形法
3.5 对偶单纯形法
3.6 固定基的参数分析
3.7 最坏情形复杂度
3.8 本章小结

取 $\omega=1$ 时，系数是 $\bar a_{2,2}=\bar a_{2,3}=-1\neq 0$，把 x_2 换入第 2 个位置，步长为零，基变为 $(1,2)$。

取 $\omega=2$ 时，系数是 $\bar a_{2,2}=\bar a_{2,3}=0$。第二行正是第一行的 2 倍，删去第二行和 x_5，基变为 (1)。

图 3.9把两阶段法的分支整理在一起。

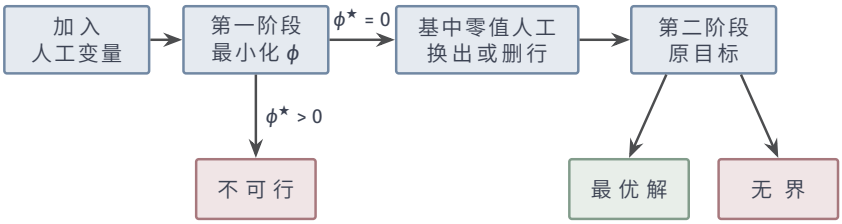


图 3.9　两阶段法的流程。第一阶段的最优值 $\phi^\star$ 决定是否继续；基中取零的人工变量换出或连同冗余行删去后，第二阶段以原目标运行，以最优解或无界方向结束。红框是给出证书的否定结果，绿框是得到最优解。

3.2.2 大 M 法

主要思想　大 M 法（big-M method）把两个阶段合成一个问题，在目标中给人工变量定一个极高的单价：

$$\min_{\boldsymbol{x},\boldsymbol{v}}\ \boldsymbol{c}^{\top}\boldsymbol{x}+M\,\mathbf{1}^{\top}\boldsymbol{v}\quad\text{s.t.}\quad \boldsymbol{A}\boldsymbol{x}+\boldsymbol{v}=\boldsymbol{b},\quad \boldsymbol{x}\geq\mathbf{0},\quad \boldsymbol{v}\geq\mathbf{0}. \tag{3.20}$$

把 M 当作一个比任何数都大的符号来计算，约化成本就是形如 $\beta+\gamma M$ 的式子，比较大小时先比 γ，再比 β。这样，只要还能减少人工变量，算法就不会先去改善原目标，排除人工变量自动享有优先权。

例中第 0 轮的对偶候选和约化成本是

$$\boldsymbol{y}=(0,0,0,M)^{\top},\quad s_1=-4-M,\quad s_2=-5-M,\quad s_6=M.$$

s_1,s_2 里 M 的系数相同，再比常数项，s_2 更负，x_2 入基。此后各轮的数据在表 3.2中，路径见图 3.10(a)。第 0 轮换基后人工变量已经出基，接下来就是用原目标继续。

t	$B^{(t)}$	(x_1, x_2)	负的约化成本（入基）
0	$(3,4,5,7)$	$(0,0)$	$s_2 = -5 - M$，$s_1 = -4 - M$
1	$(3,4,5,2)$	$(0,2)$	$s_6 = -5$
2	$(3,4,6,2)$	$(0,3)$	$s_1 = -4$
3	$(1,4,6,2)$	$(2,3)$	$s_5 = -3$
4	$(1,5,6,2)$	$(4,2)$	无，停止

表 3.2　符号化大 M 法的各轮数据。

有限的 M 要多大　实际计算若取一个具体的数 M，就必须问它够不够大。下面的定理给出精确的条件。

定理 3.7　有限惩罚的充分条件　设标准型 (3.2)有最优解，最优值为 $p^\star$，$\boldsymbol{y}^\star$ 是一个对偶最优解。若

$$M > \max_i y_i^\star, \tag{3.21}$$

其中 i 取遍带人工变量的行，则问题 (3.20)的最优值等于 $p^\star$，并且它的每个最优解都满足 $\boldsymbol{v} = \boldsymbol{0}$，其 $\boldsymbol{x}$ 部分是原问题的最优解。

证明　为简洁起见设每行都有人工变量，其余情形只需令相应 $v_i = 0$。任取问题 (3.20)的可行点 $(\boldsymbol{x}, \boldsymbol{v})$，记对偶松弛为 $\boldsymbol{s}^\star \geq \boldsymbol{0}$，它满足 $\boldsymbol{c} = \boldsymbol{s}^\star + \boldsymbol{A}^{\mathsf{T}}\boldsymbol{y}^\star$。把 $\boldsymbol{c}$ 代换掉，并用 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b} - \boldsymbol{v}$，得到

$$\boldsymbol{c}^{\mathsf{T}}\boldsymbol{x} = (\boldsymbol{s}^\star)^{\mathsf{T}}\boldsymbol{x} + (\boldsymbol{y}^\star)^{\mathsf{T}}\boldsymbol{A}\boldsymbol{x} \geq (\boldsymbol{y}^\star)^{\mathsf{T}}\boldsymbol{b} - (\boldsymbol{y}^\star)^{\mathsf{T}}\boldsymbol{v}.$$

由强对偶，$\boldsymbol{b}^{\mathsf{T}}\boldsymbol{y}^\star = p^\star$，于是两边加上 $M\boldsymbol{1}^{\mathsf{T}}\boldsymbol{v}$ 后，

$$\boldsymbol{c}^{\mathsf{T}}\boldsymbol{x} + M\boldsymbol{1}^{\mathsf{T}}\boldsymbol{v} \geq p^\star + \sum_i (M - y_i^\star) v_i \geq p^\star.$$

原问题的最优解配上 $\boldsymbol{v} = \boldsymbol{0}$ 可行且取到 $p^\star$，所以最优值是 $p^\star$。若某个最优解有 $v_i > 0$，由式 (3.21)上面最后一个不等号严格成立，与最优值为 $p^\star$ 矛盾，所以 $\boldsymbol{v} = \boldsymbol{0}$。此时 $\boldsymbol{x}$ 可行且目标为 $p^\star$，是原问题的最优解。 ■

门槛是对偶价格，这很合理：$y_i^\star$ 是放松第 i 条约束一单位时目标能下降多少，M 是违反一单位约束要付的罚款。罚款高过这个收益，违约才不划算。

这个门槛取决于事先并不知道的 $\boldsymbol{y}^\star$。把工厂的目标换成最小化成本 $2x_1 + 3x_2$，合同约束就变成活动约束，最优解是 $(2,0)$，对偶分量 $y_4^\star = 2$。

3.1 换基与最优性判别
3.2 初始可行基
3.3 退化的处理
3.4 修正单纯形法
3.5 对偶单纯形法
3.6 固定基的参数分析
3.7 最坏情形复杂度
3.8 本章小结

图 3.10(b) 对每个 M 精确求解，$M<2$ 时最优解干脆不生产，留着 $v=2$ 付罚款，$M>2$ 时才回到真正的解。

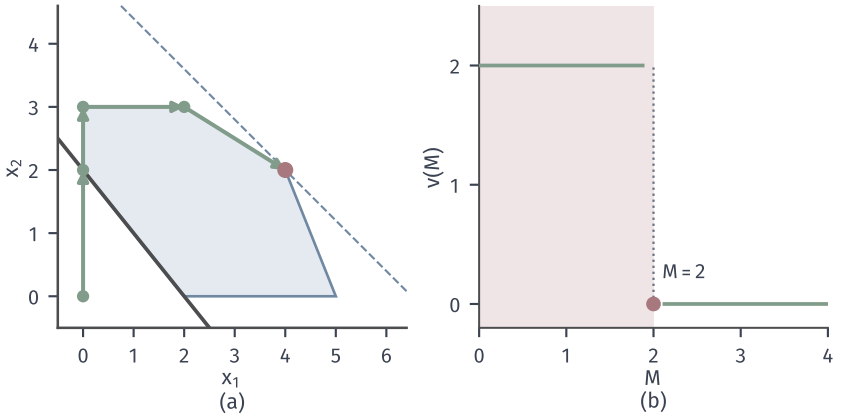


图 3.10　大 M 法。(a) 符号化大 M 在资源配置问题上的路径（绿色），第一步消去人工变量到达 $(0,2)$，其后沿边界到最优点。(b) 目标 $2x_1+3x_2+Mv$ 在不同有限 M 下的最优人工变量值 $v(M)$：红色浅底的 $M<2$ 区间内罚款不足，解停留在 $v=2$；$M=2$ 时两种解并列（点线）；$M>2$ 时 $v=0$。

M 也不能随意取大。在双精度浮点数中，10^{17} 附近相邻两个可表示数相差 16，于是

$$-4-10^{17} \quad \text{和} \quad -5-10^{17}$$

舍入后是同一个数，$c_1=-4$ 与 $c_2=-5$ 的差别被抹掉，定价失去依据。系数相差过于悬殊还会使基矩阵病态。所以有限 M 不能靠“取一个很大的常数”得到保证；另外，若某个有限 M 的解有 $v\neq\mathbf{0}$，也分不清是 M 不够大还是原问题不可行。

表 3.3对照了两种做法。

	两阶段法	大 M 法
目标	先最小化 $\mathbf{1}^{\top}\boldsymbol{v}$，再用 $\boldsymbol{c}$	同时用 $\boldsymbol{c}+M$ 惩罚
不可行判定	$\phi^{\star}>0$	符号化时 $\boldsymbol{v}$ 不能消去
参数	无	需要符号或足够大的 M
数值风险	无额外系数	M 过大使尺度恶化

表 3.3　两阶段法与大 M 法的对照。

3.3 退化的处理

定理 3.4的有限终止依赖一个假设：每次换基都能真正走出去。本节研究这个假设不成立时算法会发生什么，以及怎样修补。

同一个顶点，不同的基 把工厂的工时从 10 改成 7，三条约束边界就同时经过点 $(2,3)$，如图 3.11(a) 所示。二维平面上确定一个点只需要两条线，这里却有三条，选哪两条都行。对应到代数上，这个点的 $x_3 = x_4 = x_5 = 0$，三个变量中必须有一个留在基中，取值为零。这就是退化：一个基本可行解有基变量取零，同一个点可以对应多个基。

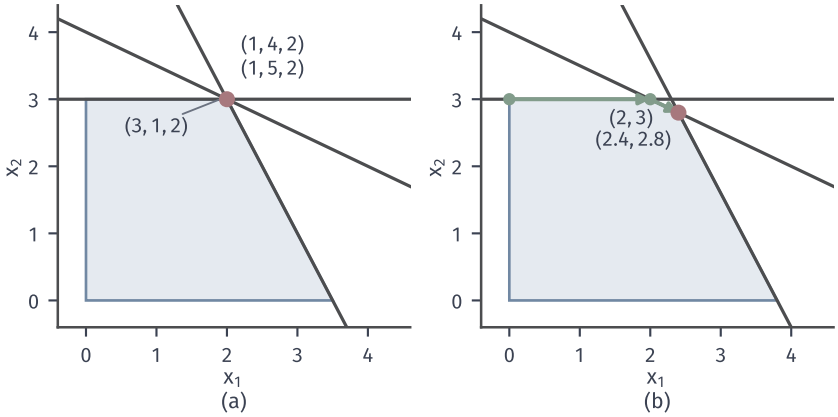


图 3.11 退化顶点及其扰动。(a) 工时取 7 时三条约束边界（深灰）交于红点 $(2,3)$，旁边的三元组是对应这同一个点的三个基。(b) 把工时夸张地增大到 7.6 后，这个顶点分裂成 $(2,3)$ 和 $(2.4,2.8)$ 两个相邻顶点，绿色路径多走一条真实的短边，每步都有实际移动。

不移动的换基 从基 $(3,4,5)$ 开始运行 Dantzig 规则，前一轮与之前相同，x_2 入基，点到 $(0,3)$，基是 $(3,4,2)$，$\boldsymbol{x}_B = (2,4,3)^{\mathsf{T}}$。下一轮 x_1 入基，$\boldsymbol{u} = (1,2,0)^{\mathsf{T}}$，两个比值并列：

$$\frac{2}{1} = 2, \qquad \frac{4}{2} = 2.$$

这里的并列正是退化的来源：两个基变量同时降到零，只有一个能出基，另一个留下来取零。按下标小的规则，x_3 出基，得到

$$B = (1,4,2), \qquad \boldsymbol{x}_B = (2,0,3)^{\mathsf{T}}, \qquad f = -23,$$

点到达 $(2,3)$。

此时的对偶候选和约化成本是

$$\boldsymbol{y} = (-4,0,3)^{\mathsf{T}}, \qquad s_3 = 4, \qquad s_5 = -3.$$

$s_5 < 0$，判别说还不能停。x_5 入基，$\boldsymbol{u} = (-2,3,1)^{\mathsf{T}}$，比值是

$$\frac{x_4}{u_2} = \frac{0}{3} = 0, \qquad \frac{x_2}{u_3} = \frac{3}{1} = 3.$$

步长 $\alpha = 0$，基变成 $(1, 5, 2)$，点和目标都没变。新基的对偶候选和约化成本是

$$\boldsymbol{y} = (-2, -1, 0)^{\mathsf{T}}, \qquad s_3 = 2, \qquad s_4 = 1,$$

全部非负，算法才停下。

其实 $(2, 3)$ 早已是最优点，这一轮换基只是把基换成能出示证书的那一个。如果上一轮并列时让 x_4 出基，就直接得到基 $(3, 1, 2)$，此时 $\boldsymbol{y} = (0, -2, -3)^{\mathsf{T}}$，$s_4 = 2$，$s_5 = 3$，立即停止。这说明两点：退化基上 $s_j < 0$ 并不表示当前点不是最优；证书依赖基，同一个最优点上有的基能给出证书，有的基不能。

循环 既然目标可以不下降，“每步都变好”的论证就失效了，算法可能在一组基之间兜圈子，这称为**循环**（cycling）。下面是一个有三行四个决策变量的例子，x_5, x_6, x_7 是松弛变量：

$$\begin{aligned} \min \quad & -10x_1 + 57x_2 + 9x_3 + 24x_4 \\ \text{s.t.} \quad & \tfrac{1}{2}x_1 - \tfrac{11}{2}x_2 - \tfrac{5}{2}x_3 + 9x_4 + x_5 = 0, \\ & \tfrac{1}{2}x_1 - \tfrac{3}{2}x_2 - \tfrac{1}{2}x_3 + x_4 + x_6 = 0, \\ & x_1 + x_7 = 1, \qquad \boldsymbol{x} \geq \boldsymbol{0}. \end{aligned} \tag{3.22}$$

用 Dantzig 规则，比值并列时取下标最小者，从基 $(5, 6, 7)$ 出发，得到表 3.4的序列。每一步都有负的约化成本，每一步的步长都是零，第 6 步回到起点。

t	$B^{(t)}$	入基	约化成本	出基
0	$(5, 6, 7)$	x_1	-10	x_5
1	$(1, 6, 7)$	x_2	-53	x_6
2	$(1, 2, 7)$	x_3	$-29/2$	x_1
3	$(3, 2, 7)$	x_4	-18	x_2
4	$(3, 4, 7)$	x_5	$-21/2$	x_3
5	$(5, 4, 7)$	x_6	-24	x_4
6	$(5, 6, 7)$	回到第 0 轮		

表 3.4 问题 (3.22)在 Dantzig 规则下的循环。

图 3.12把这六个基画成一个环。这个环上 $\boldsymbol{x}$ 从未变化，所以只看目标值的话，看不出算法在做什么。

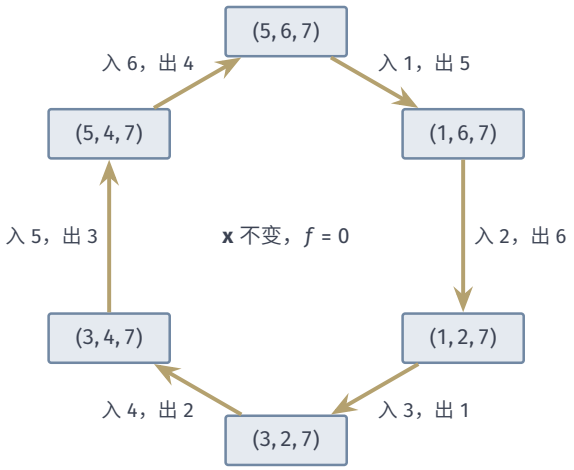


图 3.12 问题 (3.22)的六个基组成的循环。方框是基，黄色箭头是 Dantzig 规则下的一次换基，箭头旁写明入基和出基下标。整个环上 $\boldsymbol{x}$ 和目标值都不变。

Bland 规则 要打破循环，只需把“选哪一个”的自由度用一条固定的规则收走。Bland 规则（Bland's rule）规定：入基变量取所有 $s_j < 0$ 中下标最小的；比值检验并列时，出基变量取下标最小的[1]。

定理 3.8 Bland 规则的有限终止 在精确算术下，使用 Bland 规则的单纯形法不会循环，因而经过有限次换基后停止。

证明 假设出现循环。目标值不增，循环中目标必须保持不变，所以每一步的步长都是零，$\boldsymbol{x}$ 在整个循环中不变，记为 $\bar{\boldsymbol{x}}$。

称循环中曾经入基的下标为活跃下标，活跃下标也必定曾经出基。活跃下标在某个基中非基，所以对应的 $\bar{x}_j = 0$。设 k 是最大的活跃下标。取循环中 k 将要出基的一个基 B，此时入基的是活跃下标 $q < k$。再取循环中 k 将要入基的一个基 B'，其约化成本记为 $\boldsymbol{s}'$，对偶候选记为 $\boldsymbol{y}'$。

由基 B 和入基 q 按式 (3.8)构造方向 $\boldsymbol{d}$，它满足

$$\boldsymbol{A}\boldsymbol{d} = \boldsymbol{0}, \qquad \boldsymbol{c}^{\top}\boldsymbol{d} = s_q < 0.$$

用 $\boldsymbol{s}' = \boldsymbol{c} - \boldsymbol{A}^{\top}\boldsymbol{y}'$，得到

$$(\boldsymbol{s}')^{\top}\boldsymbol{d} = \boldsymbol{c}^{\top}\boldsymbol{d} - (\boldsymbol{y}')^{\top}\boldsymbol{A}\boldsymbol{d} = s_q < 0.$$

因此存在下标 j 使 $s'_j d_j < 0$。

[1] R. G. Bland, *New Finite Pivoting Rules for the Simplex Method* In Mathematics of Operations Research, 1977, vol. 2, no. 2, pp. 103–107

这个 j 满足 $j \notin B'$，因为 B' 的基变量 $s'_j = 0$；同时 $d_j \neq 0$，故 $j \in B$ 或 $j = q$。两种情况下 j 都在循环中某一时刻属于基或正要入基，而在 B' 非基，所以 j 是活跃下标，$j \le k$。

下面排除 $j = k$。k 在 B 中将要出基，说明 $u_k > 0$，$d_k < 0$；而 k 在 B' 中将要入基，说明 $s'_k < 0$。于是 $s'_k d_k > 0$，所以 $j \neq k$，只能 $j < k$。

Bland 规则在 B' 选了 k 入基，这说明比 k 小的下标都没有负的约化成本，所以 $s'_j \ge 0$，结合 $s'_j d_j < 0$ 得到 $s'_j > 0$，$d_j < 0$。特别地 $j \neq q$，所以 $j \in B$，且 $u_j = -d_j > 0$。又 j 活跃，$\bar{x}_j = 0$，于是 j 的比值是 0，与 k 的比值并列。$j < k$ 却没有被选中出基，这与 Bland 规则矛盾。

不循环意味着基不重复，基的个数有限，所以换基只能进行有限次。 ■

证明的结构值得留意：用最大的活跃下标构造一个对偶上的矛盾，正是“取下标最小”这个规则使矛盾成立。这个规则的作用是保证有限，不是追求速度，它常常比 Dantzig 规则走更多步。

回到问题 (3.22)，Bland 规则的前 5 步与表 3.4相同。第 5 轮基是 $(5, 4, 7)$，约化成本 $s_1 = -22$，$s_6 = -24$。Dantzig 规则选 s_6 回到起点，Bland 规则选下标小的 x_1，走出了循环。再换一次基后，x_3 入基时唯一的比值来自 x_7，$\alpha = 1$，得到

$$\boldsymbol{x} = (1, 0, 1, 0, 2, 0, 0)^{\mathsf{T}}, \qquad f = -1,$$

约化成本全部非负。图 3.13对比了两种规则的目标值。

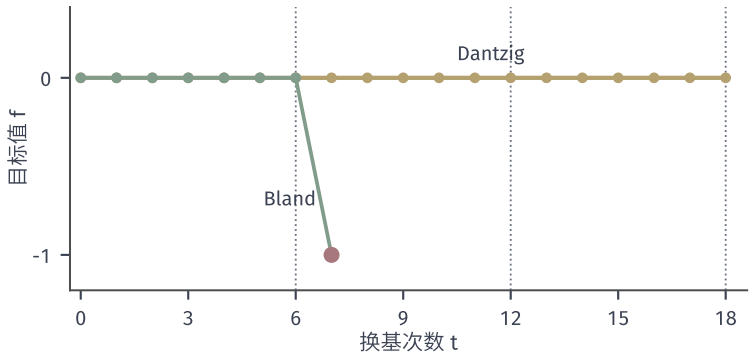


图 3.13 问题 (3.22)上两种规则的目标值。黄线是 Dantzig 规则，目标值恒为 0，竖直点线标出每 6 步回到起始基；绿线是 Bland 规则，6 次零步之后第 7 次换基走到红色的最优点，$f = -1$。

3.1 换基与最优性判别
3.2 初始可行基
3.3 退化的处理
3.4 修正单纯形法
3.5 对偶单纯形法
3.6 固定基的参数分析
3.7 最坏情形复杂度
3.8 本章小结

字典序规则 图 3.11(b) 提示了另一条路：既然麻烦来自几条约束恰好相交于一点，就把右端轻轻推开，让退化顶点裂成几个相距很近的普通顶点。把右端换成

$$\boldsymbol{b} + (\epsilon, \epsilon^2, \dots, \epsilon^m)^{\mathsf{T}},$$

其中 $\epsilon > 0$ 充分小，比值并列就不会发生，每步都有严格的下降。

字典序规则（lexicographic rule）把这个想法做成不需要真的取 ϵ 的规则：比值并列时，比较各并列行的向量 $[\bar{x}_{B(i)}, (\boldsymbol{A}_B^{-1})_{i,:}]/u_i$，取字典序最小者出基。它的作用等同于对无穷小的扰动做比值检验。证明需要跟踪各行字典序为正这一性质，并说明每次换基使目标行严格字典序下降，读者可查阅线性规划专著[2]。结论同样是：在精确算术下不循环，有限终止。

两种规则的保证都建立在精确算术之上。浮点计算里，“恰好是零”没有意义，比值并列要用容差判断，舍入误差也会把退化基上的零扰动成微小的正负数。所以实现时除了防循环的规则，还要在最后重新核查可行性和约化成本，第 3.4节将说明怎样做。

[2] D. Bertsimas, J. N. Tsitsiklis, *Introduction to Linear Optimization*, Athena Scientific, 1997

3.4 修正单纯形法

前面把算法写成了矩阵公式，每轮都出现 $\boldsymbol{A}_B^{-1}$。接下来要弄清：真正计算时应该保存什么，每轮要做多少运算？

完整的单纯形表 最直接的办法是把所有非基变量的表示都算出来，存成一张表。**单纯形表**（simplex tableau）的主体是 $\boldsymbol{A}_B^{-1}[\boldsymbol{b}\ \ \boldsymbol{A}]$，再加一行约化成本。例中第 2 轮的基是 $(1, 4, 2)$，表 3.5的上半部分就是这张表，每一列都是对应 $\boldsymbol{a}_j$ 在当前基下的表示，u 和 $\bar{x}_B$ 都可以直接读出。

换基就是对这张表做一次 Gauss–Jordan 消元，主元取在出基行和入基列的交点。例中主元是 x_4 行 x_5 列的 3。把该行除以 3，再用它消去 x_5 列的其他元素，就得到下半部分，也就是第 3 轮的表。

基	$\bar{x}$	x_1	x_2	x_3	x_4	x_5
x_1	2	1	0	1	0	-2
x_4	3	0	0	-2	1	3
x_2	3	0	1	0	0	1
$\boldsymbol{s}$	23	0	0	4	0	-3
x_1	4	1	0	$-1/3$	$2/3$	0
x_5	1	0	0	$-2/3$	$1/3$	1
x_2	2	0	1	$2/3$	$-1/3$	0
$\boldsymbol{s}$	26	0	0	2	1	0

表 3.5 资源配置问题第 2 轮（上）和第 3 轮（下）的单纯形表。第二列是基变量取值，$\boldsymbol{s}$ 行第二列是利润 $-f$，其余是约化成本。

这张表手算方便，但代价不小：每轮要更新大约 $(m+1)(n+1)$ 个数，无论这一轮用到多少。而且 $\boldsymbol{A}$ 稀疏时，$\boldsymbol{A}_B^{-1}\boldsymbol{A}$ 通常是稠密的，存储量也不可接受。

每轮真正需要什么 回头看第 3.1节的计算步骤，一轮只用到四样东西：解一次 $\boldsymbol{A}_B^{\mathsf{T}}\boldsymbol{y}=\boldsymbol{c}_B$，用 $\boldsymbol{y}$ 和 $\boldsymbol{A}$ 的非基列做内积定价，对入基列解一次 $\boldsymbol{A}_B\boldsymbol{u}=\boldsymbol{a}_q$，再做比值检验。表中其他列的表示从未被使用。**修正单纯形法**（revised simplex method）因此只维护基矩阵的因子，其余的量需要时再算。一轮的数据流如图 3.14所示。

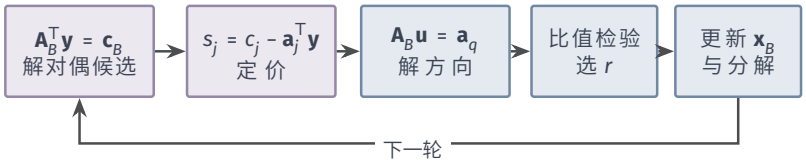


图 3.14 修正单纯形法一轮的数据流。紫色框处理对偶量：解 $\boldsymbol{A}_B^{\mathsf{T}}\boldsymbol{y}=\boldsymbol{c}_B$ 得到对偶候选，再对非基列定价。蓝色框处理原始量：解 $\boldsymbol{A}_B\boldsymbol{u}=\boldsymbol{a}_q$，比值检验选出基位置，更新基变量和基矩阵的因子。

基矩阵逆的更新 相邻两轮的基矩阵只差一列，无需重新分解。设新基 B' 把第 r 列换成 $\boldsymbol{a}_q$。由 $\boldsymbol{a}_q=\boldsymbol{A}_B\boldsymbol{u}$，新基矩阵可以写成

$$\boldsymbol{A}_{B'}=\boldsymbol{A}_B\boldsymbol{F},$$

其中 $\boldsymbol{F}$ 是把单位矩阵第 r 列换成 $\boldsymbol{u}$ 的矩阵。两边求逆，只需要 $\boldsymbol{F}$ 的逆，它仍是单位矩阵只改第 r 列的形状：

$$\boldsymbol{A}_{B'}^{-1} = \boldsymbol{E}\boldsymbol{A}_{B}^{-1}, \qquad \boldsymbol{E}_{:,r} = \boldsymbol{\eta}, \qquad \eta_i = \begin{cases} -u_i/u_r, & i \neq r, \\ 1/u_r, & i = r. \end{cases} \tag{3.23}$$

这样的 $\boldsymbol{E}$ 只需保存一列，称为 eta 矩阵。

例中从第 2 轮到第 3 轮，$\boldsymbol{u} = (-2, 3, 1)^{\top}$，$r = 2$，于是

$$\boldsymbol{E} = \begin{bmatrix} 1 & 2/3 & 0 \\ 0 & 1/3 & 0 \\ 0 & -1/3 & 1 \end{bmatrix}.$$

第 2 轮的基矩阵逆左乘 $\boldsymbol{E}$，就得到第 3 轮的基矩阵逆：

$$\boldsymbol{A}_{B^{(3)}}^{-1} = \boldsymbol{E} \begin{bmatrix} 1 & 0 & -2 \\ -2 & 1 & 3 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} -1/3 & 2/3 & 0 \\ -2/3 & 1/3 & 1 \\ 2/3 & -1/3 & 0 \end{bmatrix}. \tag{3.24}$$

这个矩阵的第 r 行就是式 (3.19)中的 $\boldsymbol{\rho}$，后两节会反复用到它。

运算量的比较　表 3.6列出每轮的存储和运算。这里 nnz(·) 表示非零元个数。修正法的优势在 $n \gg m$ 或 $\boldsymbol{A}$ 稀疏时最明显：定价只碰 $\boldsymbol{A}$ 的非零元，解方程只碰因子的非零元。

实现方式	存储	每轮主要运算
完整单纯形表	$(m+1)(n+1)$	约 mn 次更新
修正法，稠密逆	m^2	约 $m^2 + \mathrm{nnz}(\boldsymbol{A})$
修正法，LU 加 eta	因子的非零元	两次三角回代加定价

表 3.6　单纯形法几种实现的每轮代价，均指量级。

稀疏性　大规模问题的基矩阵往往非常稀疏，这时不应显式保存逆。图 3.15是一个 40 阶三对角矩阵的例子。矩阵本身和它的 LU 因子都只有 118 个非零位置，而逆矩阵的 1600 个元素全部非零。实际软件保存基矩阵经过行列重排的 LU 分解，再累积一串 eta 矩阵，这也是用稀疏因子代替稠密逆的具体办法。重排的目的是减少分解过程中新产生的非零元；LU 分解和三角回代的基本算法，可参考卷二第 12 章“线性方程的直接求解”。

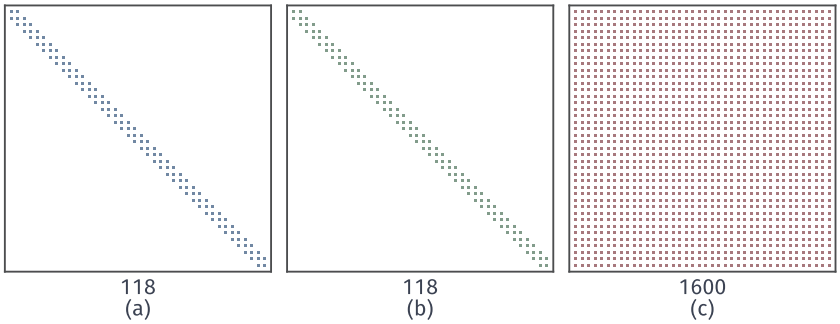


图 3.15 40 阶三对角基矩阵的非零结构，每个小点是一个非零元，图下的数字是非零元总数。(a) 矩阵本身。(b) 不选主元的 LU 因子合在一起，没有新增非零元。(c) 逆矩阵，全部 1600 个元素非零。

舍入误差 连续用 eta 矩阵更新，每一步都要除以 u_r。若主元 u_r 很小，比如 10^{-12}，$\boldsymbol{\eta}$ 的元素可达 10^{12} 量级，舍入误差被同比放大，并一直留在后续的所有计算里。图 3.16是一个固定随机种子的实验：在 120 阶稠密随机基矩阵上连续换入随机列，比较选取不同主元的残差。总选最大的主元时残差始终在 10^{-13} 左右；总选合格主元中最小的那个时，残差上升好几个数量级，定期重新分解能把它拉回来，但只要继续用小主元，残差又会很快上升。

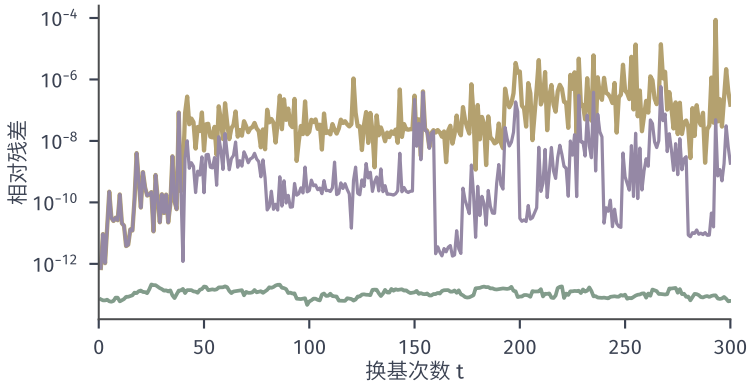


图 3.16 用更新后的逆求 $\boldsymbol{x}_B$ 时的相对残差 $\|\boldsymbol{A}_B\boldsymbol{x}_B-\boldsymbol{b}\|_2/\|\boldsymbol{b}\|_2$，随机种子固定，矩阵阶数 120。绿线每步选最大主元且不重分解；黄线每步选 $|u_r|>10^{-4}$ 中最小的主元且不重分解；紫线的选法同黄线，但每 40 次换基重新计算一次逆。

实验提示了实现时的几条具体做法。比值检验并列或接近并列时，优先选 $|u_r|$ 大的主元，低于主元容差的不选。累积若干个 eta 矩阵后，重新分解 $\boldsymbol{A}_B$，用新因子重算 $\boldsymbol{x}_B,\boldsymbol{y},\boldsymbol{s}$。

浮点数下的“非负”也只能在容差内判断。常见的可行性容差在 10^{-9} 到 10^{-6} 之间，即接受 $x_j\ge-\varepsilon$，约化成本用同样的方式判断。因此算法报告“最优”的含义是：在给定容差下，$\boldsymbol{Ax}=\boldsymbol{b}$ 的残差、$\boldsymbol{x}$ 的负部和 $\boldsymbol{s}$ 的负

3.1 换基与最优性判别
3.2 初始可行基
3.3 退化的处理
3.4 修正单纯形法
3.5 对偶单纯形法
3.6 固定基的参数分析
3.7 最坏情形复杂度
3.8 本章小结

部都足够小。收尾时应该用新的分解重算一遍这三个量，并做必要的尺度还原，因为这些容差是在内部缩放后的问题上判断的，换回原单位后需要另行核查。

3.5 对偶单纯形法

工厂解完问题后，资源情况变了：原料增加到 13，工时骤减到 2，设备增加到 4。这就需要回答：手里的最优基还能怎样利用，而不必从头求解？

基的两种可行性 约化成本只依赖 $\boldsymbol{c}$ 和基，与 $\boldsymbol{b}$ 无关。所以右端变化后，原来的最优基 $(1,5,2)$ 依然满足 $\boldsymbol{s}\ge\boldsymbol{0}$，也就是对偶可行。受影响的是基变量。用式 (3.24)的逆矩阵计算，新的基变量是

$$\boldsymbol{x}_B=\boldsymbol{A}_B^{-1}\begin{bmatrix}13\\2\\4\end{bmatrix}=\begin{bmatrix}-3\\-4\\8\end{bmatrix}.$$

基失去了原始可行性，而对偶可行性完好。这正好与上一节相反：原始单纯形法保持 $\boldsymbol{x}_B\ge\boldsymbol{0}$，逐步争取 $\boldsymbol{s}\ge\boldsymbol{0}$；现在我们手里是 $\boldsymbol{s}\ge\boldsymbol{0}$，需要逐步争取 $\boldsymbol{x}_B\ge\boldsymbol{0}$。**对偶单纯形法**（dual simplex method）做的就是这件事。

主要思想 选一个 $\bar{x}_{B(r)}<0$ 的位置，让这个基变量出基。写出第 r 行，由式 (3.4)和式 (3.19)，每个满足等式的点都有

$$x_{B(r)}+\sum_{j\in N}\bar{a}_{r,j}x_j=\bar{x}_{B(r)}<0. \tag{3.25}$$

要把 $x_{B(r)}$ 抬到零，必须让某个 $\bar{a}_{r,j}<0$ 的非基变量变大。候选可能有好几个，选哪一个由对偶可行性决定。

换到对偶的角度看。沿方向 $\boldsymbol{\rho}$ 改变对偶变量，令 $\boldsymbol{y}(\tau)=\boldsymbol{y}-\tau\boldsymbol{\rho}$，$\tau\ge0$。第一，对偶目标增大，这是我们想要的：

$$\boldsymbol{b}^{\top}\boldsymbol{y}(\tau)=\boldsymbol{b}^{\top}\boldsymbol{y}-\tau\,\bar{x}_{B(r)},$$

这里用到了 $\boldsymbol{\rho}^{\top}\boldsymbol{b}=\bar{x}_{B(r)}$。第二，约化成本线性变化：

$$s_j(\tau)=c_j-\boldsymbol{a}_j^{\top}\boldsymbol{y}+\tau\,\boldsymbol{a}_j^{\top}\boldsymbol{\rho}=s_j+\tau\,\bar{a}_{r,j}. \tag{3.26}$$

其他基变量的 $\bar{a}_{r,j}=0$，它们的约化成本保持为零；第 r 个基变量的 $\bar{a}_{r,j}=1$，约化成本变为 $\tau\geq 0$。非基变量中 $\bar{a}_{r,j}\geq 0$ 的不会变差，$\bar{a}_{r,j}<0$ 的会下降，下降到零时就必须停止。这就是对偶的比值检验：

$$\tau^{\star}=\min_{j\in N:\,\bar{a}_{r,j}<0}\frac{s_j}{-\bar{a}_{r,j}}. \tag{3.27}$$

取到最小值的 q 入基，它的约化成本恰好变成零，所有约化成本仍然非负。

对比原始比值检验：原始检验防止基变量变负，选最先碰零的基变量出基；对偶检验防止约化成本变负，选最先碰零的非基变量入基。两者结构完全对称。表 3.7列出这种对称。

	原始单纯形法	对偶单纯形法
保持	$\boldsymbol{x}_B\geq\mathbf{0}$	$\boldsymbol{s}\geq\mathbf{0}$
争取	$\boldsymbol{s}\geq\mathbf{0}$	$\boldsymbol{x}_B\geq\mathbf{0}$
先选	$s_q<0$，入基	$\bar{x}_{B(r)}<0$，出基
比值检验选	出基位置	入基下标
目标值	单调下降	单调上升
否定结论	无界	不可行

表 3.7　原始单纯形法与对偶单纯形法的对照。

式 (3.25)也解释了没有候选时的结论。若所有 $\bar{a}_{r,j}\geq 0$，式 (3.25)左端对任何 $\boldsymbol{x}\geq\mathbf{0}$ 都非负，右端却是负数，所以无解。

定理 3.9　对偶单纯形法的不可行证书　设 $\bar{x}_{B(r)}<0$，且所有 $j\in N$ 都有 $\bar{a}_{r,j}\geq 0$，则 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$，$\boldsymbol{x}\geq\mathbf{0}$ 无解，$\boldsymbol{\rho}$ 满足

$$\boldsymbol{A}^{\top}\boldsymbol{\rho}\geq\mathbf{0},\qquad \boldsymbol{b}^{\top}\boldsymbol{\rho}=\bar{x}_{B(r)}<0. \tag{3.28}$$

证明　基列的 $\boldsymbol{\rho}^{\top}\boldsymbol{a}_j$ 是 0 或 1，非基列的 $\boldsymbol{\rho}^{\top}\boldsymbol{a}_j=\bar{a}_{r,j}\geq 0$，所以 $\boldsymbol{A}^{\top}\boldsymbol{\rho}\geq\mathbf{0}$；$\boldsymbol{b}^{\top}\boldsymbol{\rho}$ 是 $\boldsymbol{A}_B^{-1}\boldsymbol{b}$ 的第 r 个分量。若有可行点 $\boldsymbol{x}$，则

$$0\leq\boldsymbol{x}^{\top}\boldsymbol{A}^{\top}\boldsymbol{\rho}=\boldsymbol{b}^{\top}\boldsymbol{\rho}<0,$$

矛盾。 ∎

变量　沿用原始单纯形法的 $B^{(t)}, \boldsymbol{x}_B^{(t)}, \boldsymbol{y}^{(t)}, \boldsymbol{s}^{(t)}, \boldsymbol{u}^{(t)}$，另增下面的量。

- $r^{(t)}$：出基位置，$p^{(t)} = B^{(t)}(r^{(t)})$ 是出基下标。
- $\boldsymbol{\rho}^{(t)} \in \mathbb{R}^m$：$\boldsymbol{A}_B^{-\top}\boldsymbol{e}_r$；$\bar{a}_{r,j}^{(t)}$：第 r 行对第 j 列的系数。
- $\tau^{(t)} \geq 0$：对偶步长；$q^{(t)}$：入基下标；$\alpha^{(t)}$：原始步长。

初始化　需要一个对偶可行基。例中取原来的最优基，数据由式 (3.13)和上面的计算得到：

$$B^{(0)} = (1, 5, 2), \qquad \boldsymbol{x}_B^{(0)} = (-3, -4, 8)^\top, \qquad \boldsymbol{y}^{(0)} = (-2, -1, 0)^\top.$$

约化成本是 $s_3 = 2$，$s_4 = 1$，对偶目标 $\boldsymbol{b}^\top \boldsymbol{y}^{(0)} = -28$。这个 -28 比原问题的最优值低，它是新问题最优值的一个下界，算法要把它抬高。

每轮更新 第 t 轮依次做下面几步。步骤后的“例中”是第 0 轮的数据。

1. 判别。若 $\boldsymbol{x}_B^{(t)} \geq \mathbf{0}$，停止，当前解最优。否则选负分量位置 r 出基，常取最负的。例中最负的是 $x_5 = -4$：

$$r^{(0)} = 2, \qquad p^{(0)} = 5.$$

2. 计算第 r 行。由式 (3.19)，例中取式 (3.24)的第 2 行：

$$\boldsymbol{\rho}^{(0)} = \left(-\frac{2}{3}, \frac{1}{3}, 1\right)^{\top}, \qquad \bar{a}_{2,3} = -\frac{2}{3}, \qquad \bar{a}_{2,4} = \frac{1}{3}.$$

3. 对偶比值检验。若所有 $\bar{a}_{r,j} \geq 0$，停止，按定理 3.9报告不可行。否则由式 (3.27)确定 $\tau^{(t)}$ 和 $q^{(t)}$。例中只有 x_3 是候选：

$$\tau^{(0)} = \frac{2}{2/3} = 3, \qquad q^{(0)} = 3.$$

4. 更新对偶量。沿 $\boldsymbol{\rho}$ 移动，由式 (3.26)更新约化成本：

$$\boldsymbol{y}^{(t+1)} = \boldsymbol{y}^{(t)} - \tau^{(t)}\boldsymbol{\rho}^{(t)}, \qquad s_j^{(t+1)} = s_j^{(t)} + \tau^{(t)}\bar{a}_{r,j}^{(t)}. \tag{3.29}$$

例中

$$\boldsymbol{y}^{(1)} = (0, -2, -3)^{\top}, \qquad s_4^{(1)} = 1 + 3 \cdot \frac{1}{3} = 2, \qquad s_5^{(1)} = 3.$$

5. 更新原始量。先求 $\boldsymbol{u}^{(t)} = \boldsymbol{A}_B^{-1}\boldsymbol{a}_q$，取原始步长 $\alpha^{(t)} = \bar{x}_{B(r)}/\bar{a}_{r,q}$，它是让第 r 个基变量恰好变成零的步长。其余基变量按式 (3.11)更新，第 r 个位置放 $x_q = \alpha^{(t)}$。例中

$$\boldsymbol{u}^{(0)} = \left(-\frac{1}{3}, -\frac{2}{3}, \frac{2}{3}\right)^{\top}, \qquad \alpha^{(0)} = \frac{-4}{-2/3} = 6.$$

于是

$$B^{(1)} = (1, 3, 2), \qquad \boldsymbol{x}_B^{(1)} = (-1, 6, 4)^{\top}, \qquad \boldsymbol{b}^{\top}\boldsymbol{y}^{(1)} = -16.$$

例中第 1 轮只剩 $x_1 = -1$ 为负，所以 $r = 1$，x_1 出基。第 1 行的系数和唯一的候选是

$$\boldsymbol{\rho}^{(1)} = \left(0, \frac{1}{2}, -\frac{1}{2}\right)^{\top}, \qquad \bar{a}_{1,4} = \frac{1}{2}, \qquad \bar{a}_{1,5} = -\frac{1}{2}, \qquad \tau^{(1)} = \frac{3}{1/2} = 6.$$

于是 x_5 入基，由式 (3.29)得到

$$\boldsymbol{y}^{(2)} = (0, -5, 0)^{\top}, \qquad s_1^{(2)} = 6, \qquad s_4^{(2)} = 2 + 6 \cdot \frac{1}{2} = 5.$$

原始量的更新用

$$\boldsymbol{u}^{(1)} = \left(-\frac{1}{2}, -\frac{3}{2}, 1\right)^{\top}, \qquad \alpha^{(1)} = \frac{-1}{-1/2} = 2,$$

更新后得到

$$B^{(2)} = (5, 3, 2), \qquad \boldsymbol{x}_B^{(2)} = (2, 9, 2)^{\top}, \qquad \boldsymbol{b}^{\top}\boldsymbol{y}^{(2)} = -10.$$

第 2 轮 $\boldsymbol{x}_B \geq \mathbf{0}$，算法停止。

最终得到 新问题的最优解和最优值是

$$(x_1, x_2) = (0, 2), \qquad p^{\star} = -10.$$

工时只有 2，全部给利润率更高的产品二最合算。对偶目标依次是 $-28, -16, -10$，每一步增加 $\tau|\bar{x}_{B(r)}|$，即 $3 \cdot 4 = 12$ 和 $6 \cdot 1 = 6$，它们一直是最优值的下界，到达时恰好等于最优值。这与第 3.1节目标从上方下降的情形相反。

图 3.17(a) 显示了路径的特点：前两个点 $(-3, 8)$ 和 $(-1, 4)$ 都在可行域之外，它们是一系列“太便宜而不可能达到”的解，算法一步步向可行域靠拢，碰到可行域时恰好最优。

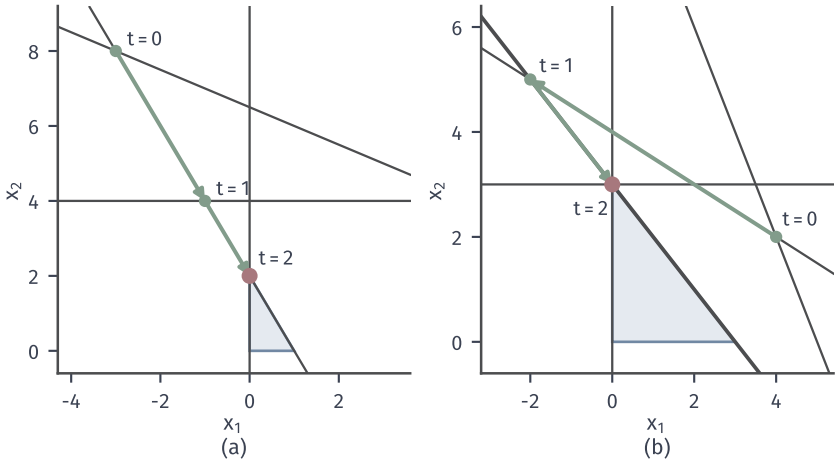


图 3.17 对偶单纯形法在原始空间的路径（绿色），深灰线是约束边界，浅蓝是可行域，红点是最优解。(a) 右端变为 $(13, 2, 4)$ 后，从不可行点 $(-3, 8)$ 经 $(-1, 4)$ 到 $(0, 2)$。(b) 新增约束 $x_1 + x_2 \leq 3$（粗线）后，从原最优点 $(4, 2)$ 经不可行点 $(-2, 5)$ 到 $(0, 3)$。

新增约束与基的复用 加入新约束是另一种常见的情形。给工厂加一条约束 $x_1 + x_2 \leq 3$，并引入松弛变量 x_6。把 x_6 放入基，原最优基扩展成

$(1,5,2,6)$。新基对偶可行，因为新列只增加一个取零的约化成本；只有 x_6 可能违反非负，这里 $x_6 = 3 - 6 = -3$。

第 0 轮 x_6 出基，第 4 行的系数和两个候选比值是

$$\bar{a}_{4,3} = -\frac{1}{3}, \qquad \bar{a}_{4,4} = -\frac{1}{3}, \qquad \frac{2}{1/3} = 6, \qquad \frac{1}{1/3} = 3.$$

图 3.18把这两个比值画成约化成本随 τ 下降的直线，s_4 先碰到零，所以 x_4 入基。再经一轮换基，$\boldsymbol{x}_B$ 全部非负，得到 $(x_1, x_2) = (0, 3)$，利润 15。

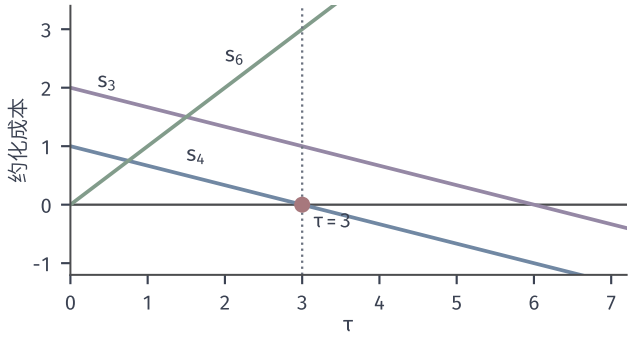


图 3.18　新增约束后第 0 轮的对偶比值检验。三条直线是约化成本随对偶步长 τ 的变化：$s_3 = 2 - \tau/3$，$s_4 = 1 - \tau/3$，$s_6 = \tau$。红点是最先降到零的位置 $\tau = 3$，它决定入基变量 x_4；s_6 对应出基的 x_6，只增不减。

如果新增的约束与资源不相容，比如 $x_1 + x_2 \geq 7$，化为 $-x_1 - x_2 + x_6 = -7$ 后，第一轮 $x_6 = -1$，第 4 行是

$$x_6 + \frac{1}{3}x_3 + \frac{1}{3}x_4 = -1.$$

系数全部非负而右端为负，这正是定理 3.9的情形，算法一步报告不可行。这和第 3.2.1节第一阶段得到的结论相同，证书都是原料和工时约束的组合。

这种利用已有基的做法称为**热启动**（warm start）。它是整数规划算法的基本工序：分支限界在线性松弛的解上增加一个变量界，割平面增加一条被当前解违反的不等式，两者都只在原问题上添一点约束，原来的最优基仍然对偶可行。对偶单纯形法往往只需少量换基就能恢复可行，比从头求解省得多。热启动的效果依赖新约束对解的改变有多大，并没有通用的步数保证。

3.1 换基与最优性判别
3.2 初始可行基
3.3 退化的处理
3.4 修正单纯形法
3.5 对偶单纯形法
3.6 固定基的参数分析
3.7 最坏情形复杂度
3.8 本章小结

3.6 固定基的参数分析

上一节处理了参数变化之后怎样重新求解。本节问得更早一步：参数在多大范围内变化时，原来的最优基根本不用换，最优解和最优值又怎样随参数变化。

固定最优基 $B^\star = (1, 5, 2)$。式 (3.24)给出了它的逆矩阵，所有结论都来自这个矩阵。基保持最优需要两个条件：$\boldsymbol{x}_B \geq \boldsymbol{0}$ 保证原始可行，$\boldsymbol{s} \geq \boldsymbol{0}$ 保证对偶可行。右端变化只影响前者，目标系数变化只影响后者。

右端变化 设第 i 个资源变化 δ，即 $\boldsymbol{b}(\delta) = \boldsymbol{b} + \delta \boldsymbol{e}_i$。基不变时，基变量和目标值都是 δ 的线性函数：

$$\boldsymbol{x}_B(\delta) = \bar{\boldsymbol{x}}_B + \delta\, \boldsymbol{A}_B^{-1}\boldsymbol{e}_i, \qquad f(\delta) = p^\star + \delta\, y_i. \tag{3.30}$$

第二个式子由 $f = \boldsymbol{b}^\top \boldsymbol{y}$ 和 $\boldsymbol{y}$ 不随 $\boldsymbol{b}$ 变化得到。基保持可行的条件是 $\boldsymbol{x}_B(\delta) \geq \boldsymbol{0}$，这是对 δ 的一组线性不等式，解出来是一个区间。

以原料 $b_1 = 8 + \delta$ 为例，$\boldsymbol{A}_B^{-1}\boldsymbol{e}_1$ 是式 (3.24)的第一列，于是

$$x_1 = 4 - \frac{1}{3}\delta, \qquad x_5 = 1 - \frac{2}{3}\delta, \qquad x_2 = 2 + \frac{2}{3}\delta.$$

三个非负条件分别要求

$$\delta \leq 12, \qquad \delta \leq \frac{3}{2}, \qquad \delta \geq -3.$$

取交集，$\delta \in [-3, 3/2]$，也就是 $b_1 \in [5, 9.5]$。图 3.19(a) 展示了这个范围的几何意义：b_1 变化时，原料线平行移动，最优顶点沿工时线滑动，下端碰到 $x_2 = 0$，上端碰到设备约束，再走基就要换了。

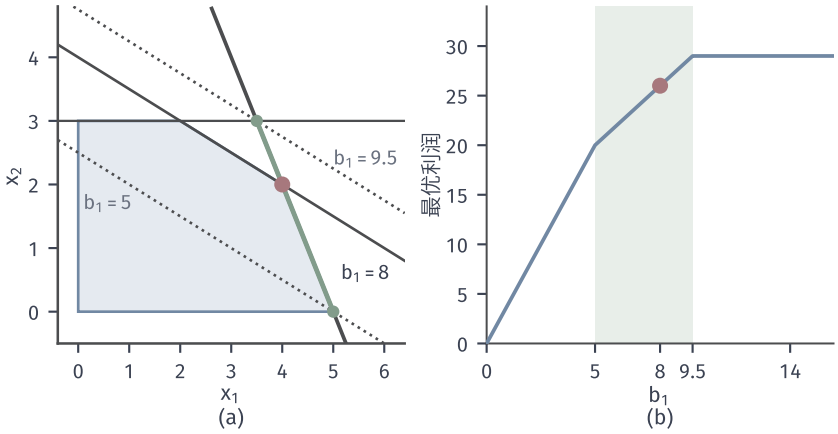


图 3.19 原料 b_1 的有效范围。(a) 实线和点线是 $b_1 = 8$ 及范围两端 $b_1 = 5, 9.5$ 的原料线，绿色线段是最优顶点随 b_1 滑过的路径，红点是 $b_1 = 8$ 的最优点。(b) 最优利润随 b_1 的变化（蓝线，对每个 b_1 精确求解），绿色底是基 $(1, 5, 2)$ 的有效范围，其中斜率恒为影子价格 2，范围之外斜率改变。

影子价格 在有效范围内，y_i 就是目标对 b_i 的变化率。按最大化利润的语言，它的相反数是多一单位资源带来的额外利润，称为**影子价格**（shadow price）。例中

$$-y_1^\star = 2, \qquad -y_2^\star = 1, \qquad -y_3^\star = 0.$$

一单位原料值 2，一单位工时值 1，设备还有富余，增加设备不值钱。如果市场上原料的单价低于 2，就值得购买，但这个判断只在 $b_1 \le 9.5$ 之内有效。超过这个范围，图 3.19(b) 的斜率变成了 0，因为此时专用设备成了新的瓶颈。“影子价格”是局部的，它是某个固定基上的数，不是资源的绝对价值。

目标系数变化 设基变量 x_k 的成本变化 δ，$k = B(\ell)$，$\boldsymbol{c}(\delta) = \boldsymbol{c} + \delta \boldsymbol{e}_k$。此时 $\boldsymbol{x}$ 不变，对偶候选变化，由式 (3.5)计算得到

$$s_j(\delta) = s_j - \delta\, \bar{a}_{\ell,j} \quad (j \in N), \qquad f(\delta) = p^\star + \delta\, x_k^\star. \tag{3.31}$$

其中 $\bar{a}_{\ell,j}$ 是第 ℓ 行的系数。基保持最优的条件是 $s_j(\delta) \ge 0$。若变化的是非基变量 x_j 的成本，只影响它自己的 s_j，最优基在 $s_j + \delta \ge 0$ 时不变。

以产品一的利润为例，x_1 位于基的第 1 个位置，第 1 行的系数由式 (3.24)的第一行得到，$\bar{a}_{1,3} = -\frac{1}{3}$，$\bar{a}_{1,4} = \frac{2}{3}$。于是

$$s_3(\delta) = 2 + \frac{1}{3}\delta, \qquad s_4(\delta) = 1 - \frac{2}{3}\delta.$$

非负条件给出 $\delta \in [-6, 3/2]$。由 $c_1 = -4 + \delta$，换成产品一的利润 $p_1 = 4 - \delta$，范围是 $p_1 \in [2.5, 10]$。

图 3.20说明了这个区间。利润向量转动时，等值线绕最优点转动，最优点保持不动，直到等值线与某条活动约束重合。$p_1 = 2.5$ 时利润向量平行于 $(1, 2)$，$p_1 = 10$ 时平行于 $(2, 1)$，两个端点正好是两条活动约束的法向。

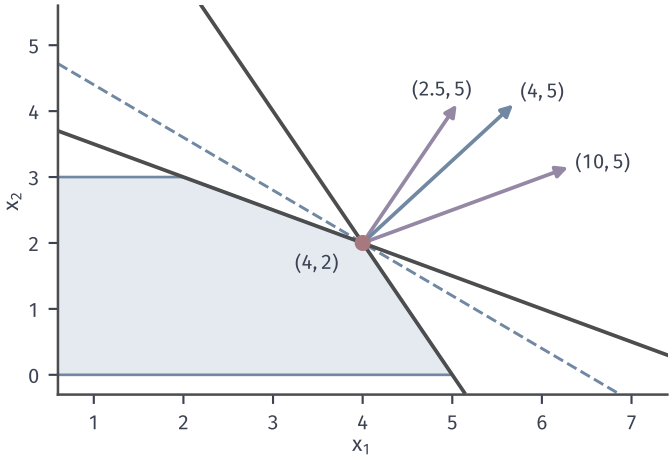


图 3.20　产品一利润 p_1 的有效范围。深灰粗线是过 $(4, 2)$ 的两条活动约束，蓝色虚线是当前利润 $p_1 = 4$ 的等值线。三支箭头只表示方向：蓝色是当前利润向量，紫色是范围端点 $p_1 = 2.5$ 和 $p_1 = 10$ 的利润向量，两者分别垂直于两条活动约束。

表 3.8列出全部五个参数的结果。

参数	当前值	有效范围	变化率
b_1	8	$[5,\ 9.5]$	利润 $+2$
b_2	10	$[7,\ 16]$	利润 $+1$
b_3	3	$[2,\ \infty)$	利润不变
p_1	4	$[2.5,\ 10]$	利润 $+x_1^\star = +4$
p_2	5	$[2,\ 8]$	利润 $+x_2^\star = +2$

表 3.8　单个参数变化时最优基 $(1, 5, 2)$ 的有效范围，变化率指参数每增加一单位时最优利润的变化，只在范围内有效。

几个参数同时变化时，结论要从向量形式读取。设右端变化 $\Delta\boldsymbol{b}$，基 B 保持可行的条件是

$$\bar{\boldsymbol{x}}_B + \boldsymbol{A}_B^{-1}\Delta\boldsymbol{b} \geq \boldsymbol{0}.$$

这是 $\Delta\boldsymbol{b}$ 的一个多面体，不是逐个区间的乘积。把各个单独的范围同时用到极端，可能已经出界。

越出范围之后　范围的端点不是答案的终点，只是这个基失效的位置。越过右端的范围，基失去原始可行性而保持对偶可行，这正是第 3.5节的出

3.1 换基与最优性判别
3.2 初始可行基
3.3 退化的处理
3.4 修正单纯形法
3.5 对偶单纯形法
3.6 固定基的参数分析
3.7 最坏情形复杂度
3.8 本章小结

发点。例如 $b_1 = 11$ 时 $x_5 = -1$，对偶单纯形法一次换基就得到基 $(1,3,2)$ 和解 $(7/2, 3)$，利润 29，这与图 3.19(b) 的平台一致。

越过目标系数的范围,基失去对偶可行性而保持原始可行,这时用原始单纯形法接着走。例如 $p_1 = 12$ 时 $s_3 = -2/3, x_3$ 入基,$\boldsymbol{u} = (-1/3, -2/3, 2/3)^{\mathsf{T}}$,比值检验给出 x_2 出基，点走到 $(5,0)$，利润 60。

把一个个基的有效范围拼起来，最优值就成为参数的分段线性函数,图 3.19(b) 是一个例子，折点是换基发生的位置。在一般约束下，值函数和解映射如何随参数变化，由第 19章研究。

3.7 最坏情形复杂度

单纯形法有限终止，但有限不等于快。换基次数在最坏情况下能有多大,它和一次换基的代价是什么关系，实际表现又该怎样理解?

换基次数与每轮代价 总运算量是两个因子的乘积：换基次数乘以每轮代价。第 3.4节处理的是后者，稠密实现下每轮是 m 和 n 的低次多项式。本节讨论前者。基的个数最多是从 n 个下标中选 m 个的组合数，随规模指数增长，所以有限终止本身给不出多项式界。问题在于，算法会不会真的走那么多步。

Klee–Minty 构造 下面这族例子表明确实可能。第 n 个问题有 n 个变量和 n 个约束：

$$\begin{aligned} \max \quad & z_n = \sum_{j=1}^{n} 2^{n-j} x_j \\ \text{s.t.} \quad & x_i + \sum_{j<i} 2^{i-j+1} x_j \le 5^i, \quad i = 1, \dots, n, \\ & \boldsymbol{x} \ge \boldsymbol{0}. \end{aligned} \tag{3.32}$$

它属于 Klee 和 Minty 提出的压扁立方体构造[3]。$n = 2$ 时约束是 $x_1 \le 5$, $4x_1 + x_2 \le 25$，目标是 $2x_1 + x_2$。从原点出发，Dantzig 规则选系数大的 x_1，走到 $(5,0)$；接着 x_2 入基，走到 $(5,5)$；最后第一个松弛变量入基，走到 $(0,25)$。四个顶点全被访问，如图 3.21所示。

[3] V. Klee, G. J. Minty, “How Good Is the Simplex Algorithm?”, in: *Inequalities III*, ed. by O. Shisha, New York: Academic Press, 1972, pp. 159–175

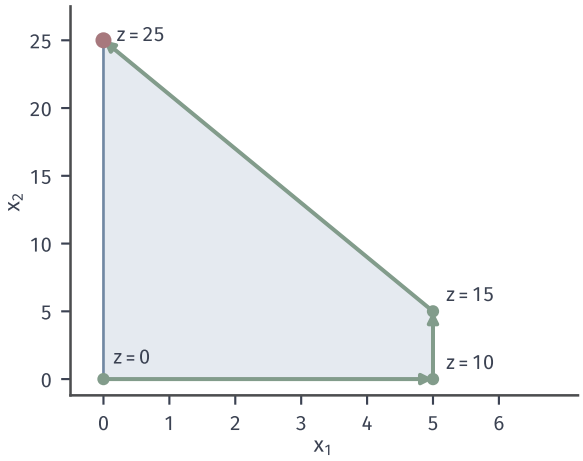


图 3.21 $n = 2$ 的 Klee–Minty 问题。可行域（浅蓝）有四个顶点，绿色路径依次访问全部四个，每个顶点旁标出目标值 z，红点是最优解 $(0, 25)$。注意最优点其实与起点相邻，算法却绕了远路。

$n = 3$ 时情况相同，图 3.22是可行域的示意。路径走完底面的四个顶点，上升一次，再把顶面的四个顶点反向走一遍。

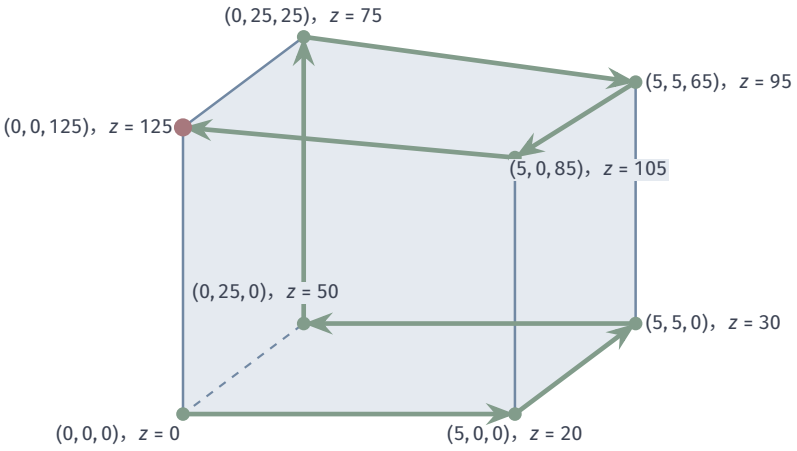


图 3.22 $n = 3$ 的 Klee–Minty 问题的示意，画成立方体，顶点坐标和目标值 z 是真实数据，比例不真实。绿色路径是 Dantzig 规则访问的顺序，共 7 次换基、走遍 8 个顶点，红点是最优解。

这种“走完一面、再反着走一遍”的结构可以写成对 n 的归纳。为了写证明，先观察目标和约束之间的递推关系。记第 i 个松弛变量为 w_i。由式 (3.32)，第 n 个目标和第 n 个约束都可以用 z_{n-1} 表示：

$$z_n = 2z_{n-1} + x_n, \qquad w_n = 5^n - x_n - 4z_{n-1}. \tag{3.33}$$

前 $n-1$ 个约束恰好是第 $n-1$ 个问题的约束，其中不含 x_n 和 w_n。

下面用“字典”的语言：字典是把基变量和目标写成非基变量函数的表达式，也就是式 (3.4)和式 (3.6)的另一种叫法。最大化时，Dantzig 规则选目标表达式中系数最大的正系数变量入基，这与最小化标准型中选最负的 s_j 是同一条规则。

定理 3.10　Klee–Minty 问题的换基次数　对问题 (3.32)，从全部松弛变量组成的基出发，Dantzig 规则恰好经过 2^n-1 次换基到达最优解，最优值为 5^n。

证明　对 n 归纳证明一个更强的命题。把从全松弛基出发、最大化 z_n 的运行称为上行，记为 U_n；把从 U_n 的终点出发、最大化 $-z_n$ 的运行称为下行，记为 D_n。命题是：U_n 和 D_n 各有 2^n-1 次换基；U_n 过程中 z_n 从 0 增加到 5^n，D_n 过程中 z_n 从 5^n 减少到 0 并回到全松弛基；所有字典的目标系数都是整数。

$n=1$ 时 $z_1=x_1$，$w_1=5-x_1$。上行时 x_1 入基，一次换基后 $z_1=5-w_1$。下行时目标是 $-z_1=-5+w_1$，w_1 入基，一次换基后 $-z_1=-x_1$。命题成立。

设命题对 $n-1$ 成立，先看 U_n。由式 (3.33)，它分三段。

第一段。设第 $n-1$ 个问题的字典中 z_{n-1} 的系数为 d_k，它们是整数。此时 z_n 的系数是 $2d_k$，而 x_n 的系数是 1。只要有 $d_k>0$，就有 $2d_k\ge 2>1$，Dantzig 规则的选择与 U_{n-1} 完全相同。第 n 行也不起限制作用，因为 $x_n=0$ 且 $z_{n-1}\le 5^{n-1}$，由式 (3.33)得

$$w_n \ge 5^n - 4\cdot 5^{n-1} = 5^{n-1} > 0.$$

所以算法照搬 U_{n-1}，$2^{n-1}-1$ 次换基后 $z_{n-1}=5^{n-1}$，所有 $d_k\le 0$。

第二段。此时只有 x_n 的系数为正，它入基。x_n 只出现在第 n 行，所以 w_n 出基，$x_n=5^{n-1}$。这是一次换基。把 $x_n=5^n-w_n-4z_{n-1}$ 代入 z_n，目标变为

$$z_n = 5^n - w_n - 2z_{n-1}.$$

第三段。现在 w_n 的系数是 -1，其余系数是 $-2d_k$，后者正是 D_{n-1} 的目标 $-z_{n-1}$ 放大 2 倍，w_n 的系数为负，不会入基。第 n 行现在是 $x_n=5^n-w_n-4z_{n-1}$，$w_n=0$ 时 $x_n\ge 5^{n-1}>0$，不起限制作用。所以算法照搬 D_{n-1}，$2^{n-1}-1$ 次换基后 $z_{n-1}=0$，所有系数非正，算法停止，此时 $z_n=5^n$。

三段合计 $2(2^{n-1}-1)+1=2^n-1$ 次换基。

再看 D_n，它从 $-z_n=-5^n+w_n+2z_{n-1}$ 开始，z_{n-1} 的字典是全松弛基。第一段中 w_n 的系数是 1，其余是 $2d_k$，同样的比较说明算法照搬 U_{n-1}，第 n 行 $x_n\ge 5^{n-1}>0$ 不起限制作用。第二段只有 w_n 的系数为正，它入基，x_n 出基，代入后目标变为

$$-z_n=-x_n-2z_{n-1}.$$

第三段照搬 D_{n-1}，第 n 行 $w_n\ge 5^{n-1}>0$ 不起限制作用，最后回到全松弛基，$z_n=0$。

整数性由式 (3.33)的递推保持，因为各段目标都是归纳假设中的整数系数乘 ±2 再加上系数为 ±1 的 x_n 或 w_n。归纳完成。 ■

证明的要点在于系数的差距：前 $n-1$ 个变量的系数翻倍，所以只要还有事可做，Dantzig 规则就不会理会 x_n；右端 5^i 的快速增长保证第 n 行不起限制作用。换一种规则结论就可能改变，图 3.23(a) 中 Bland 规则在这族例子上的步数少一些，但这只说明这族例子不是专门针对 Bland 规则构造的，其他构造同样能使 Bland 规则走指数多步。是否存在一条换基规则能保证多项式次换基，至今没有答案。

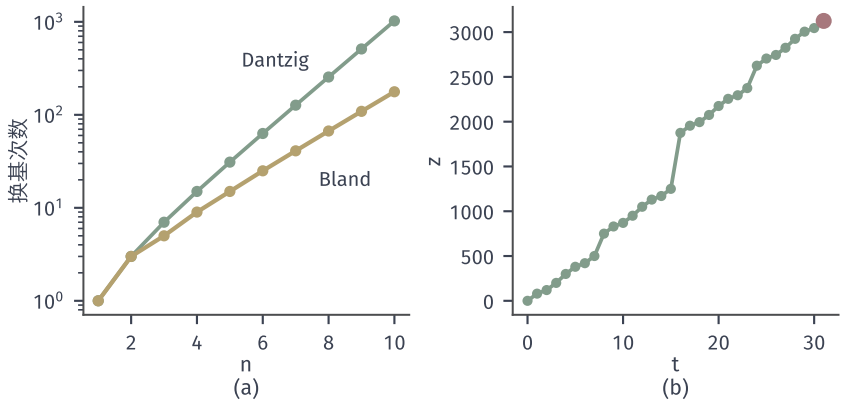


图 3.23 Klee–Minty 问题的实测结果，精确有理数运算。(a) 换基次数随 n 变化，纵轴取对数；绿线是 Dantzig 规则，恰为 2^n-1；黄线是 Bland 规则。(b) $n=5$ 时 Dantzig 规则各步的目标值，共 31 步，红点是最优值 3125。

最坏情形与实际表现 定理 3.10是对一族特殊问题的结论，并不刻画算法在一般问题上的行为。长期的实践表明，单纯形法在大多数实际问题上的换基次数远小于组合数，常是约束数的不大的倍数。

3.1 换基与最优性判别
3.2 初始可行基
3.3 退化的处理
3.4 修正单纯形法
3.5 对偶单纯形法
3.6 固定基的参数分析
3.7 最坏情形复杂度
3.8 本章小结

图 3.24是一个小实验：$\boldsymbol{A},\boldsymbol{c}$ 的元素在 $(0,1)$ 上独立均匀抽取，$\boldsymbol{b}=\mathbf{1}$，$m=n$，每种规模取 30 个随机种子。平均换基次数随规模温和增长，$m=320$ 时约 655 次，比 Klee–Minty 问题的指数增长慢得多。

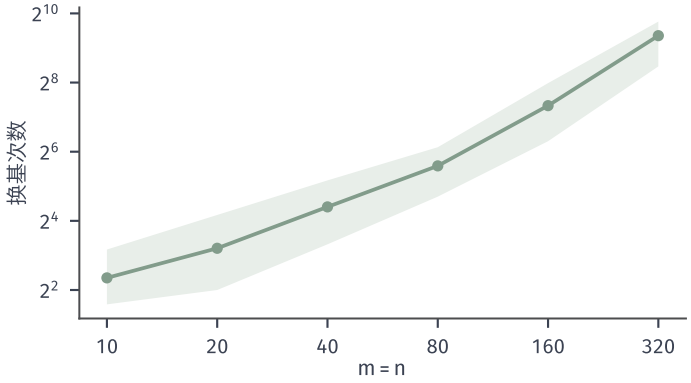


图 3.24　一种随机模型上 Dantzig 规则的换基次数，两轴都是对数刻度。绿线是 30 个随机种子的平均值，浅绿色带是最小值到最大值的范围。实验条件：$m=n$，$\boldsymbol{A},\boldsymbol{c}$ 的元素在 $(0,1)$ 上独立均匀，$\boldsymbol{b}=\mathbf{1}$，起始基是全松弛基。

这个实验只说明这一随机模型上的情况，不能外推成对任意问题的保证。实际问题带有特定的结构，有时比随机模型容易，有时因退化严重而困难得多。理论上也有在特定随机扰动模型下给出多项式期望步数的结果，那些结论依赖扰动模型，并不告诉我们某一个具体实例要走多少步。

所以这里的两个判断要分开说：最坏情形下，Dantzig 规则的换基次数可以随维数指数增长，这是定理；实际问题上换基次数通常不大，这是经验观察，没有无条件的平均复杂度保证。这个差别也是下一章研究多项式时间方法的原因之一。

3.8 本章小结

本章开头的问题是怎样在有限但极多的顶点之间找到最优的一个。单纯形法的回答是：用基来表示顶点，用约化成本判断哪条边值得走，用比值检验决定走多远，用对偶候选写出最优性证书。工厂的例子经过三次换基，从 $(0,0)$ 走到 $(4,2)$，并得到资源的对偶价格 $(2,1,0)$。

算法的每个环节都有明确的条件。起步需要可行基，没有时用人工变量，两阶段法或符号化的大 M 法把它们排除；有限的 M 要超过对偶价格，这一点事先并不知道。退化基使步长为零，同一点对应多个基，循环可能发生，Bland 规则或字典序规则在精确算术下保证有限终止。实现上修正单纯形法只维护基矩阵的因子，浮点运算要求小心选主元、定期重新分解，并在结束时重新核查。

算法的结果总是带着证据，表 3.9汇总了三种停止结果。

结果	检验	证据
最优	可行基上 $\boldsymbol{s} \geq \mathbf{0}$	原始解和对偶解，目标相等
无界	$s_q < 0$ 且 $\boldsymbol{u} \leq \mathbf{0}$	可行点和方向 $\boldsymbol{d}$，$\boldsymbol{c}^{\top}\boldsymbol{d} < 0$
不可行	第一阶段 $\phi^{\star} > 0$，或对偶单纯形法无候选	$\boldsymbol{y}$，满足 $\boldsymbol{A}^{\top}\boldsymbol{y} \leq \mathbf{0}$，$\boldsymbol{b}^{\top}\boldsymbol{y} > 0$（后者取 $\boldsymbol{y} = -\boldsymbol{\rho}$）

表 3.9 单纯形法的三种停止结果及其证据。

得到最优基以后，还能继续使用它。基的可行性和最优性分别管着右端和目标系数，固定基的参数分析读出每个参数的有效范围和影子价格；越出范围后，右端的变化交给对偶单纯形法，目标系数的变化交给原始单纯形法，只需少量换基。这种复用是单纯形法在整数规划等反复求解场合的重要优势。

有限终止不等于快。Klee–Minty 构造说明 Dantzig 规则的换基次数最坏可以指数增长，实践中换基次数虽然通常不大，却没有无条件的理论保证。第 4章将研究另一条路线：不沿边界走，而从可行域内部逼近最优解。

4.1 中心路径
4.2 原始—对偶路径跟踪
4.3 初始点
4.4 求解精度
4.5 多项式复杂度
4.6 单纯形法与内点法的比较
4.7 本章小结

第 4 章

内点法

第 3章的工厂问题里，单纯形法从原点出发，沿可行域的边走过几个顶点，到达最优顶点 $(4, 2)$。每到一个顶点，都要决定下一步走哪条边。顶点的数目可以随维数指数增长，第 3章末尾的构造说明，这种逐个顶点的走法在最坏情形下确实可能走遍它们。于是有一个自然的问题：能不能不贴着边走，而从可行域的中间穿过去？

穿过中间要解决三件事。一是在内部靠什么指路：内部的每个点都可行，目标又是线性的，梯度处处相同，单看目标看不出该往哪里停。二是怎样防止撞上边界，同时又让终点能落在边界上，因为线性规划的最优解总在边界上。三是走到什么程度算完：内部的点永远不会恰好是顶点，“差不多最优”要有能核对的含义。

本章的回答是第 2章对偶理论的一个直接延伸。把互补松弛条件 $x_i s_i = 0$ 放宽成 $x_i s_i = \mu$，再让正数 μ 逐渐减小到零，方程组的解就连成一条从内部通向最优面的光滑曲线。第一节建立这条曲线，第二节用 Newton 法沿它前进，并在一个能手算的小例子上逐轮写出全部计算。

后面四节处理算法落地时的问题。起点从哪里来，放在第三节；三项残差怎样决定停止、近似解怎样变成基和严格证书，放在第四节；第五节证明一种路径跟踪规则的迭代次数只随 $\sqrt{n}$ 增长，并说明这和线性规划的多项式可解性是什么关系；最后一节在工厂问题上把内点法和单纯形法放在一起比较。一般非线性约束上的内点法由第 24章讨论。

4.1 中心路径

在可行域内部，沿怎样一条路线走，才能既不撞上边界，又最终到达最优解？答案是一条由对偶理论确定的曲线。我们先回顾要用到的对偶事实，再从一维的障碍函数讲起。

标准型与对偶　本章讨论第 2章的标准型线性规划及其对偶：

$$\min_{\boldsymbol{x}} \ \boldsymbol{c}^{\top}\boldsymbol{x} \quad \text{s.t.} \quad \boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}, \quad \boldsymbol{x} \geq \boldsymbol{0}, \tag{4.1}$$

$$\max_{\boldsymbol{y},\boldsymbol{s}} \ \boldsymbol{b}^{\top}\boldsymbol{y} \quad \text{s.t.} \quad \boldsymbol{A}^{\top}\boldsymbol{y}+\boldsymbol{s}=\boldsymbol{c}, \quad \boldsymbol{s}\geq\boldsymbol{0}, \tag{4.2}$$

其中 $\boldsymbol{A}\in\mathbb{R}^{m\times n}$ 满行秩，$\boldsymbol{y}\in\mathbb{R}^{m}$ 无符号限制，$\boldsymbol{s}\in\mathbb{R}^{n}$ 称为对偶松弛。两个最优值分别记为 $p^{\star}$ 和 $d^{\star}$。

那一章的两个结论是本章的出发点。第一个是目标差的恒等式：若 $\boldsymbol{x}$ 原始可行，$(\boldsymbol{y},\boldsymbol{s})$ 对偶可行，把 $\boldsymbol{c}=\boldsymbol{A}^{\top}\boldsymbol{y}+\boldsymbol{s}$ 和 $\boldsymbol{b}=\boldsymbol{A}\boldsymbol{x}$ 代入目标差，得到

$$\boldsymbol{c}^{\top}\boldsymbol{x}-\boldsymbol{b}^{\top}\boldsymbol{y}=(\boldsymbol{A}^{\top}\boldsymbol{y}+\boldsymbol{s})^{\top}\boldsymbol{x}-(\boldsymbol{A}\boldsymbol{x})^{\top}\boldsymbol{y}=\boldsymbol{x}^{\top}\boldsymbol{s}. \tag{4.3}$$

左边称为对偶间隙。因为 $\boldsymbol{x},\boldsymbol{s}\geq\boldsymbol{0}$，它非负，这就是弱对偶。

第二个是强对偶：问题可行且最优值有限时，$p^{\star}=d^{\star}$。于是 $(\boldsymbol{x},\boldsymbol{y},\boldsymbol{s})$ 最优，当且仅当它同时满足

$$\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}, \qquad \boldsymbol{A}^{\top}\boldsymbol{y}+\boldsymbol{s}=\boldsymbol{c}, \qquad x_i s_i=0\,(i=1,\dots,n), \qquad \boldsymbol{x},\boldsymbol{s}\geq\boldsymbol{0}. \tag{4.4}$$

中间的条件是互补松弛。前两组方程是线性的，难处全在 $x_i s_i=0$：对每个下标，要决定是 x_i 为零还是 s_i 为零。这是一个组合选择，单纯形法用基来做这个选择，一次换基改动一个下标。

全章贯穿下面这个小例子，只有一条等式约束：

$$\min_{\boldsymbol{x}} \ x_1+2x_2+3x_3 \quad \text{s.t.} \quad x_1+x_2+x_3=1, \quad \boldsymbol{x}\geq\boldsymbol{0}. \tag{4.5}$$

这里 $n=3$，$m=1$，$\boldsymbol{A}=[1\ 1\ 1]$，$b=1$，$\boldsymbol{c}=(1,2,3)^{\top}$。可行集是 $\mathbb{R}^3$ 中以三个单位向量为顶点的三角形。

对偶约束是 $y+s_i=c_i$，即 $\boldsymbol{s}=(1-y,\,2-y,\,3-y)^{\top}$，$\boldsymbol{s}\geq\boldsymbol{0}$ 等价于 $y\leq 1$，对偶目标就是 y 本身。最优解和最优对偶解都一眼可得：

$$\boldsymbol{x}^{\star}=(1,0,0)^{\top}, \qquad y^{\star}=1, \qquad \boldsymbol{s}^{\star}=(0,1,2)^{\top}, \qquad p^{\star}=d^{\star}=1.$$

可以核对 $x_i^{\star}s_i^{\star}$ 全为零。

贴边走与穿过去　图 4.1是第 3章的工厂问题。黄线是单纯形法的路线，它贴着边界，在三个拐角上各做了一次选择。绿线是本节要建立的路径，它从内部一个点出发，平滑地弯向最优顶点，途中不需要决定任何“走哪条边”的问题。

可以把可行域想成一间房间，最优解在墙角。贴墙走，每到拐角都要判断往哪边转；从房间中央穿过去，没有拐角，但需要两样东西：一种不让人撞墙的力，以及一种随时间减弱这个力的办法，否则永远到不了墙角。这个比喻在终点处失效：真正的解就在墙上，所以排斥力必须在极限中消失，下面的 $\mu\downarrow 0$ 就是这件事。

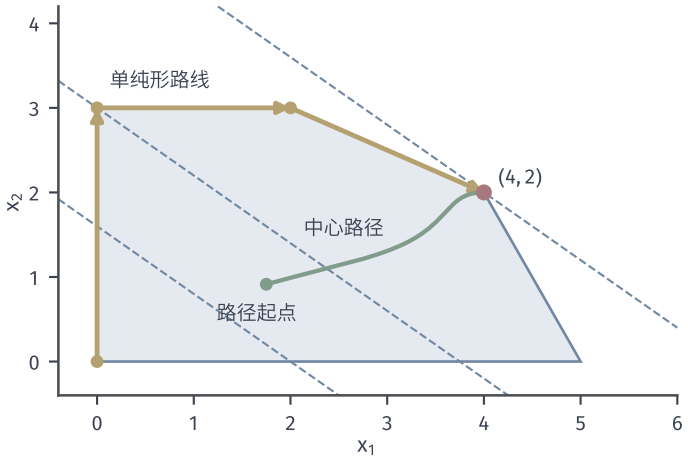


图 4.1　工厂问题的两条路线。浅蓝区域是可行域，蓝色虚线是利润的等值线，红点是最优顶点 $(4,2)$。黄线是单纯形法经过的顶点序列 $(0,0)$、$(0,3)$、$(2,3)$、$(4,2)$；绿线是中心路径，从 μ 很大时的内部点出发，随 μ 减小弯向最优顶点，全程不碰边界。

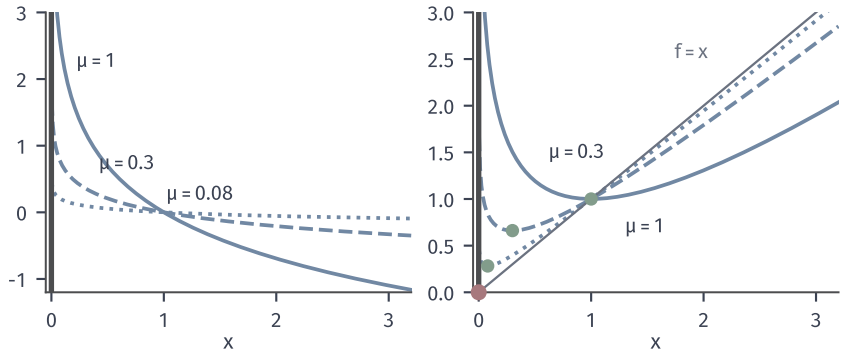
一维的障碍　先看最简单的情形：在 $x \geq 0$ 上最小化 $f(x) = x$，解是边界点 $x = 0$。在目标上加一项 $-\mu \log x$，其中 $\mu > 0$，它在 $x \downarrow 0$ 时趋于 $+\infty$，像一堵逐渐升高的墙，把迭代挡在 $x > 0$ 的一侧。这时要解的是

$$\min_{x>0} \; x - \mu \log x.$$

令导数 $1 - \mu/x$ 为零，得到唯一的最小点

$$x = \mu.$$

图 4.2显示了两件事。图 (a) 中，μ 越小，墙贴得越紧，离墙稍远的地方几乎不受影响。图 (b) 中，绿点是加了障碍后的最小点，它随 μ 减小沿 $x = \mu$ 滑向真正的解 $x = 0$。



(a) 障碍项 (b) 目标加障碍项

图 4.2 一维的对数障碍。(a) 障碍项 $-\mu\log x$，实线、虚线、点线分别对应 $\mu = 1, 0.3, 0.08$，深灰粗线是边界 $x = 0$。(b) 目标 $f(x) = x$（细灰线）加上障碍项后的三条曲线，绿点是各自的最小点 $x = \mu$，红点是真正的解 $x = 0$。

对数障碍问题 回到问题 (4.1)，对每个坐标都加一项障碍。这里要留意“内部”的含义。例 (4.5)的可行集是 $\mathbb{R}^3$ 中的一块三角形，厚度为零，没有通常意义下的内点。障碍只负责不等式 $\boldsymbol{x} \geq \boldsymbol{0}$，等式 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 始终严格保持，所以内部是相对等式约束而言的，指满足等式且所有分量为正的点。

定义 4.1 严格可行 满足 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 且 $\boldsymbol{x} > \boldsymbol{0}$ 的点称为原始严格可行（strictly feasible）点。满足 $\boldsymbol{A}^{\top}\boldsymbol{y} + \boldsymbol{s} = \boldsymbol{c}$ 且 $\boldsymbol{s} > \boldsymbol{0}$ 的 $(\boldsymbol{y}, \boldsymbol{s})$ 称为对偶严格可行点。两者都存在时，记

$$\mathcal{F}^{\circ} = \{(\boldsymbol{x}, \boldsymbol{y}, \boldsymbol{s}) : \boldsymbol{A}\boldsymbol{x} = \boldsymbol{b},\ \boldsymbol{A}^{\top}\boldsymbol{y} + \boldsymbol{s} = \boldsymbol{c},\ \boldsymbol{x} > \boldsymbol{0},\ \boldsymbol{s} > \boldsymbol{0}\}. \tag{4.6}$$

严格可行点不一定存在。约束 $x_1 + x_2 = 0$、$\boldsymbol{x} \geq \boldsymbol{0}$ 的可行集只有原点，其中没有正的点。例 (4.5)中，$\boldsymbol{x} = (1/3, 1/3, 1/3)^{\top}$ 与 $y = 0$、$\boldsymbol{s} = (1, 2, 3)^{\top}$ 都严格可行。

对 $\mu > 0$，定义**对数障碍**（logarithmic barrier）问题

$$\min_{\boldsymbol{x}}\ B_{\mu}(\boldsymbol{x}) = \boldsymbol{c}^{\top}\boldsymbol{x} - \mu\sum_{i=1}^{n}\log x_i \quad \text{s.t.} \quad \boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}, \quad \boldsymbol{x} > \boldsymbol{0}. \tag{4.7}$$

图 4.3画出例 (4.5)中 B_{μ} 的等值线。线性目标本身没有碗底，障碍项在三条边上竖起墙，围出一个碗。μ 大时碗底靠近三角形中央，μ 小时墙贴向边界，碗底被线性目标推向最优顶点。

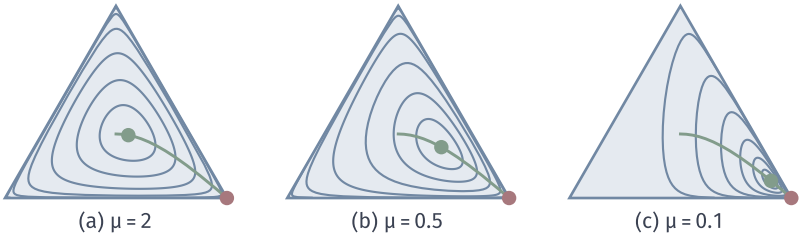


图 4.3 例 (4.5)的障碍目标 B_μ 在三角形上的等值线（蓝线）。绿线是全部碗底连成的曲线，绿点是当前 μ 的碗底，红点是最优顶点。μ 减小时，碗底沿绿线向红点移动，碗也越来越贴近边界。

一阶条件给出扰动的互补 B_μ 的梯度是 $\boldsymbol{c} - \mu \boldsymbol{X}^{-1}\mathbf{1}$，其中 $\boldsymbol{X} = \operatorname{diag}(\boldsymbol{x})$，$\mathbf{1}$ 是全一向量。在仿射集合 $\{\boldsymbol{x} : \boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}\}$ 上，能移动的方向是 $\boldsymbol{A}$ 的零空间，一阶条件要求梯度与零空间正交。$\boldsymbol{A}$ 的零空间的正交补是 $\boldsymbol{A}^\top$ 的列空间，所以一阶条件是：存在 $\boldsymbol{y}$ 使

$$\boldsymbol{c} - \mu \boldsymbol{X}^{-1}\mathbf{1} = \boldsymbol{A}^\top \boldsymbol{y}.$$

这里出现了一个与 $\boldsymbol{c} - \boldsymbol{A}^\top \boldsymbol{y}$ 相等的正向量，正是对偶松弛的样子。令 $\boldsymbol{s} = \mu \boldsymbol{X}^{-1}\mathbf{1}$，上式成为 $\boldsymbol{A}^\top \boldsymbol{y} + \boldsymbol{s} = \boldsymbol{c}$，而 $\boldsymbol{s}$ 的定义就是 $x_i s_i = \mu$。三组条件合起来是

$$\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}, \qquad \boldsymbol{A}^\top \boldsymbol{y} + \boldsymbol{s} = \boldsymbol{c}, \qquad x_i s_i = \mu \ (i = 1, \dots, n), \qquad \boldsymbol{x}, \boldsymbol{s} > \mathbf{0}. \tag{4.8}$$

把它与最优性条件 (4.4)逐项对比，只有互补松弛一处不同：$x_i s_i = 0$ 换成了 $x_i s_i = \mu$。

图 4.4说明这个改动的好处。在 (x_i, s_i) 平面上，$x_i s_i = 0$、$x_i, s_i \geq 0$ 是一个直角折线，组合选择就是选落在哪条腿上。把它换成双曲线 $x_i s_i = \mu$，折角被磨圆了，曲线是光滑的，可以用微积分处理；μ 越小，曲线越贴近折角。

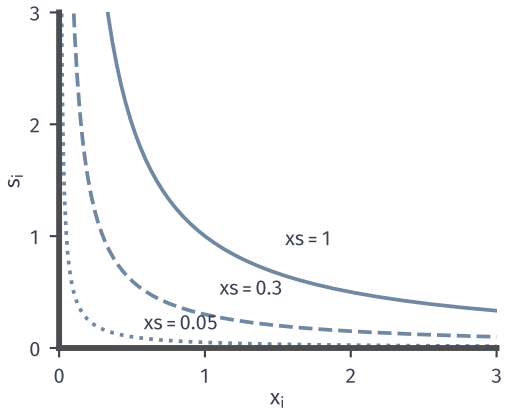


图 4.4　互补条件的光滑化。深灰粗线是 $x_i s_i = 0$、$x_i, s_i \ge 0$ 的直角折线，蓝色曲线是 $x_i s_i = \mu$，实线、虚线、点线分别对应 $\mu = 1, 0.3, 0.05$。$\mu \downarrow 0$ 时曲线贴近折线，但对每个正的 μ，x_i 和 s_i 都严格为正。

存在唯一的条件　碗底并不总是存在，下面的定理说明它需要原始和对偶两侧都有严格可行点。

定理 4.2　中心点的存在唯一　设 $\boldsymbol{A}$ 满行秩，$\mu > 0$。方程组 (4.8)有解，当且仅当 $\mathcal{F}^\circ$ 非空。此时解 $(\boldsymbol{x}(\mu), \boldsymbol{y}(\mu), \boldsymbol{s}(\mu))$ 唯一，且 $\boldsymbol{x}(\mu)$ 是障碍问题 (4.7)的唯一最小点。

证明　必要性：方程组的解本身就是 $\mathcal{F}^\circ$ 中的点。

充分性分两步。先证最小点存在。取 $(\bar{\boldsymbol{y}}, \bar{\boldsymbol{s}})$ 对偶严格可行，在原始可行点上，由 $\boldsymbol{c} = \boldsymbol{A}^{\top}\bar{\boldsymbol{y}} + \bar{\boldsymbol{s}}$ 和 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$，目标可以改写为

$$\boldsymbol{c}^{\top}\boldsymbol{x} = \boldsymbol{b}^{\top}\bar{\boldsymbol{y}} + \bar{\boldsymbol{s}}^{\top}\boldsymbol{x},$$

于是

$$B_\mu(\boldsymbol{x}) = \boldsymbol{b}^{\top}\bar{\boldsymbol{y}} + \sum_{i=1}^{n}\bigl(\bar{s}_i x_i - \mu \log x_i\bigr).$$

因为 $\bar{s}_i > 0$，每个一元函数 $\bar{s}_i t - \mu \log t$ 在 $(0, \infty)$ 上有下界，并且在 $t \downarrow 0$ 和 $t \to \infty$ 时都趋于 $+\infty$。

于是对原始严格可行点 $\boldsymbol{x}^{(0)}$，考虑下水平集

$$\bigl\{\boldsymbol{x} : \boldsymbol{A}\boldsymbol{x} = \boldsymbol{b},\ \boldsymbol{x} > \boldsymbol{0},\ B_\mu(\boldsymbol{x}) \le B_\mu(\boldsymbol{x}^{(0)})\bigr\}.$$

其中每个坐标都落在某个区间 $[\epsilon, R]$ 内，$\epsilon > 0$，这是非空紧集。连续函数在紧集上取到最小值，这就是障碍问题的一个最小点。

再证一阶条件与最小点等价，并得到唯一性。最小点在相对内部，一阶条件成立，于是得到方程组 (4.8)的一个解。反过来，设 $(\boldsymbol{x},\boldsymbol{y},\boldsymbol{s})$ 是一个解。函数 $-\log t$ 是凸函数，所以 B_μ 在可行集上是严格凸的，对任何可行的 $\boldsymbol{x}'$ 有

$$B_\mu(\boldsymbol{x}') \ge B_\mu(\boldsymbol{x}) + \nabla B_\mu(\boldsymbol{x})^{\top}(\boldsymbol{x}'-\boldsymbol{x}) = B_\mu(\boldsymbol{x}) + \boldsymbol{y}^{\top}\boldsymbol{A}(\boldsymbol{x}'-\boldsymbol{x}) = B_\mu(\boldsymbol{x}),$$

这说明 $\boldsymbol{x}$ 是最小点。严格凸性保证最小点唯一，于是 $\boldsymbol{x}$ 唯一，$\boldsymbol{s}=\mu\boldsymbol{X}^{-1}\mathbf{1}$ 也唯一。$\boldsymbol{A}^{\top}$ 列满秩，$\boldsymbol{A}^{\top}\boldsymbol{y}=\boldsymbol{c}-\boldsymbol{s}$ 给出唯一的 $\boldsymbol{y}$。 ■

对偶严格可行这个条件不能省。问题 $\min 0$、$x_1-x_2=0$、$\boldsymbol{x}\ge\mathbf{0}$ 有原始严格可行点 $(1,1)$，最优值为 0。它的障碍目标在可行射线 $x_1=x_2=r$ 上等于 $-2\mu\log r$，当 $r\to\infty$ 时趋于 $-\infty$，没有最小点。原因在对偶一侧：对偶约束 $y+s_1=0$、$-y+s_2=0$ 迫使 $s_1+s_2=0$，严格可行点不存在。

定义 4.3　中心路径　当 $\mathcal{F}^\circ$ 非空时，μ 取遍 $(0,\infty)$，方程组 (4.8)的解构成一条曲线

$$\mathcal{C}=\{(\boldsymbol{x}(\mu),\boldsymbol{y}(\mu),\boldsymbol{s}(\mu)) : \mu>0\}, \tag{4.9}$$

称为**中心路径**（central path）。其中的点称为中心点。

这个名字可以这样理解：方程组要求所有乘积 x_is_i 相等，没有哪个坐标比别的坐标更靠近自己的边界，点保持在“中央”。下面的例子把路径完整地写出来。

示例 4.4　贯穿例的中心路径　在问题 (4.5)中，$s_i=c_i-y$，$x_is_i=\mu$ 给出 $x_i=\mu/(c_i-y)$。代入 $x_1+x_2+x_3=1$，消去 $\boldsymbol{x}$，得到 μ 与 y 的关系

$$\mu=\Big(\frac{1}{1-y}+\frac{1}{2-y}+\frac{1}{3-y}\Big)^{-1},\qquad y<1.$$

所以路径可以用 y 作参数直接写出。

取 $y=0$，则 $\boldsymbol{s}=(1,2,3)^{\top}$，括号内是 $1+\frac12+\frac13=\frac{11}{6}$，于是

$$\mu=\frac{6}{11},\qquad \boldsymbol{x}=\Big(\frac{6}{11},\frac{3}{11},\frac{2}{11}\Big)^{\top}.$$

三个乘积都等于 $6/11$，三个分量之和为 1。

再取 $y=1/2$，则 $\boldsymbol{s}=(\frac12,\frac32,\frac52)^{\top}$，括号内是 $2+\frac23+\frac25=\frac{46}{15}$，于是

$$\mu=\frac{15}{46},\qquad \boldsymbol{x}=\Big(\frac{15}{23},\frac{5}{23},\frac{3}{23}\Big)^{\top}.$$

两端的行为也能读出来。$y \to -\infty$ 时 $\mu \to \infty$，x_i 趋于相等，极限是 $(1/3,1/3,1/3)^\top$。$y \uparrow 1$ 时第一项发散，$\mu \to 0$，$\boldsymbol{x} \to (1,0,0)^\top$。

图 4.5把这条路径画在三角形上。起点是 $\mu \to \infty$ 的极限，这一点最大化 $\sum_i \log x_i$，称为可行集的**解析中心**（analytic center）。解析中心只有在可行集有界时才存在，它只由约束决定，与目标无关；目标 $\boldsymbol{c}$ 的作用是决定路径离开中心后朝哪里弯。

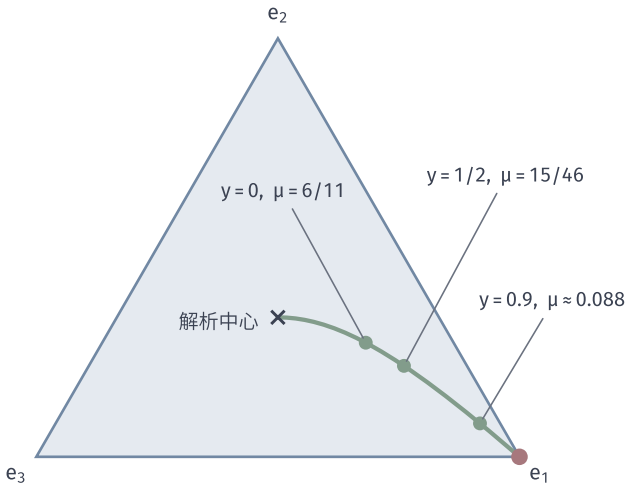


图 4.5　贯穿例的中心路径。三角形是可行集，三个角是单位向量，黑叉是解析中心 $(1/3,1/3,1/3)^\top$，绿线是中心路径，绿点是例 4.4算出的中心点以及 $y = 0.9$ 的中心点，红点是最优顶点 $\boldsymbol{e}_1$。

间隙恰好是 $n\mu$　中心路径最有用的性质是，沿路径的对偶间隙可以直接读出来。中心点原始、对偶都可行，把式 (4.3)用到这里，再代入 $x_i s_i = \mu$，得到

$$\boldsymbol{c}^\top \boldsymbol{x}(\mu) - \boldsymbol{b}^\top \boldsymbol{y}(\mu) = \sum_{i=1}^{n} x_i(\mu) s_i(\mu) = n\mu. \tag{4.10}$$

它把“还差多远”变成了一个已知的数。由弱对偶 $\boldsymbol{b}^\top \boldsymbol{y}(\mu) \le p^\star$，原始目标误差不超过间隙：

$$\boldsymbol{c}^\top \boldsymbol{x}(\mu) - p^\star \le n\mu. \tag{4.11}$$

要让误差不超过 ε，走到 $\mu \le \varepsilon/n$ 就够了。在例 4.4中，$y = 0$ 的中心点目标值是 $6/11 + 6/11 + 6/11 = 18/11$，对偶目标是 0，间隙 $18/11$ 正好等于 3μ。

这个结论用到了精确的中心点。迭代算法只能走到中心路径附近，这时间隙怎样计算，第 4.4节会逐项说明。

路径的终点 式 (4.10)说明目标值收敛到最优值，却没有说点本身收敛到哪里。解不唯一时，这个问题的答案并不平凡。先看例子：把目标换成 $c=(0,0,1)$，约束不变，此时第三个分量为零的整条边都是最优解。

这时 $\boldsymbol{s}=(-y,-y,1-y)$，记 $r=-y>0$，则 $x_1=x_2=\mu/r$，$x_3=\mu/(1+r)$，等式约束给出

$$\frac{2\mu}{r}+\frac{\mu}{1+r}=1.$$

令 $\mu\downarrow 0$，第二项趋于零，第一项必须趋于 1，所以 $r\approx 2\mu$，$x_1=x_2=\mu/r\to 1/2$。路径的极限是 $(1/2,1/2,0)^{\top}$，它不是顶点，而是最优边的中点，如图 4.6(b) 所示。

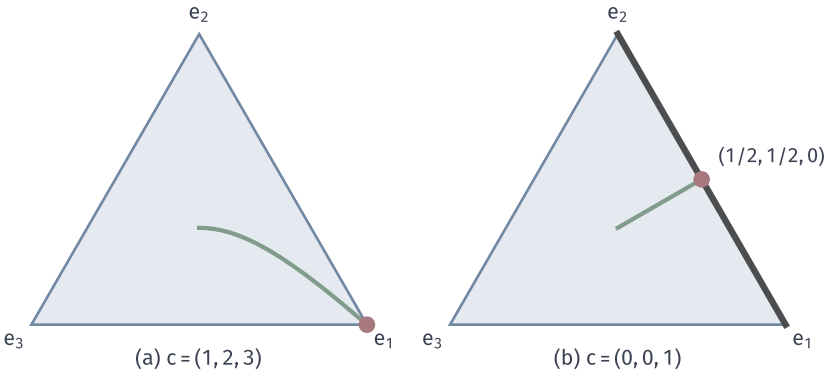


图 4.6 路径的极限由最优解集决定。绿线是中心路径。(a)$\boldsymbol{c}=(1,2,3)$，最优解唯一，路径通向顶点 $\boldsymbol{e}_1$（红点）。(b)$\boldsymbol{c}=(0,0,1)$，最优解集是深灰粗线表示的整条边，路径通向这条边的中点 $(1/2,1/2,0)^{\top}$，这是最优面上的解析中心，不是顶点。

一般情形的结论如下。设最优解集合为 $\boldsymbol{S}_{\mathrm{P}}$，这是可行集的一个面，称为**最优面**（optimal face）。若某对原始、对偶最优解满足对每个下标 $x_i^{\star}+s_i^{\star}>0$，就称这对解是**严格互补**（strictly complementary）的。下面的定理说，中心路径收敛到一对严格互补的解，并且在最优面上取在“最中央”的位置。

定理 4.5 中心路径的极限 设 $\boldsymbol{A}$ 满行秩，$\mathcal{F}^{\circ}$ 非空。当 $\mu\downarrow 0$ 时，$(\boldsymbol{x}(\mu),\boldsymbol{y}(\mu),\boldsymbol{s}(\mu))$ 收敛到一对最优解 $(\hat{\boldsymbol{x}},\hat{\boldsymbol{y}},\hat{\boldsymbol{s}})$。记 $B=\{i:\hat{x}_i>0\}$，$N=\{i:\hat{s}_i>0\}$，则 B 与 N 互不相交且并集为 $\{1,\dots,n\}$，并且 $\hat{\boldsymbol{x}}$ 是最优面上使下式最大的唯一点：

$$\sum_{i\in B}\log x_i. \tag{4.12}$$

证明　关键工具是一个正交关系。设 $\boldsymbol{x},\boldsymbol{x}'$ 都满足等式 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$，$(\boldsymbol{y},\boldsymbol{s}),(\boldsymbol{y}',\boldsymbol{s}')$ 都满足 $\boldsymbol{A}^{\top}\boldsymbol{y}+\boldsymbol{s}=\boldsymbol{c}$。则 $\boldsymbol{x}-\boldsymbol{x}'$ 属于 $\boldsymbol{A}$ 的零空间，$\boldsymbol{s}-\boldsymbol{s}'=-\boldsymbol{A}^{\top}(\boldsymbol{y}-\boldsymbol{y}')$ 属于 $\boldsymbol{A}^{\top}$ 的列空间，于是

$$(\boldsymbol{x}-\boldsymbol{x}')^{\top}(\boldsymbol{s}-\boldsymbol{s}')=0. \tag{4.13}$$

有界性。取固定的 $(\bar{\boldsymbol{x}},\bar{\boldsymbol{y}},\bar{\boldsymbol{s}})\in\mathcal{F}^{\circ}$。把式 (4.13)用到中心点和这一点，展开并用 $\boldsymbol{x}(\mu)^{\top}\boldsymbol{s}(\mu)=n\mu$，得到

$$\bar{\boldsymbol{s}}^{\top}\boldsymbol{x}(\mu)+\bar{\boldsymbol{x}}^{\top}\boldsymbol{s}(\mu)=n\mu+\bar{\boldsymbol{x}}^{\top}\bar{\boldsymbol{s}}.$$

左边各项非负且 $\bar{\boldsymbol{x}},\bar{\boldsymbol{s}}>\boldsymbol{0}$，所以 $\mu\in(0,1]$ 时 $\boldsymbol{x}(\mu)$、$\boldsymbol{s}(\mu)$ 有界。$\boldsymbol{A}^{\top}$ 列满秩，$\boldsymbol{y}(\mu)$ 也有界。

聚点是最优解。取 $\mu_k\downarrow 0$ 使三元组收敛到一个聚点 $(\hat{\boldsymbol{x}},\hat{\boldsymbol{y}},\hat{\boldsymbol{s}})$。它满足两组等式，$\hat{\boldsymbol{x}},\hat{\boldsymbol{s}}\geq\boldsymbol{0}$，且由式 (4.10)，$\hat{\boldsymbol{x}}^{\top}\hat{\boldsymbol{s}}=0$，所以是最优解。

一个归一化的恒等式。设 $(\boldsymbol{x}^{\star},\boldsymbol{y}^{\star},\boldsymbol{s}^{\star})$ 是任意一对最优解，由互补松弛，它们的内积为零。把式 (4.13)用到中心点和这一对最优解，得到

$$(\boldsymbol{s}^{\star})^{\top}\boldsymbol{x}(\mu)+(\boldsymbol{x}^{\star})^{\top}\boldsymbol{s}(\mu)=n\mu.$$

两边除以 μ，用 $x_i(\mu)/\mu=1/s_i(\mu)$ 和 $s_i(\mu)/\mu=1/x_i(\mu)$，得到

$$\sum_{i=1}^{n}\frac{s_i^{\star}}{s_i(\mu)}+\sum_{i=1}^{n}\frac{x_i^{\star}}{x_i(\mu)}=n. \tag{4.14}$$

严格互补。式 (4.14)左边每一项非负，所以 $x_i(\mu)\geq x_i^{\star}/n$。令 $\mu=\mu_k\to 0$，得 $\hat{x}_i\geq x_i^{\star}/n$，即每个最优解的正分量也是 $\hat{\boldsymbol{x}}$ 的正分量；对 $\hat{\boldsymbol{s}}$ 同理。

再把聚点 $(\hat{\boldsymbol{x}},\hat{\boldsymbol{s}})$ 本身当作最优解代入式 (4.14)，令 $\mu_k\to 0$。$i\in B$ 时 $\hat{x}_i/x_i(\mu_k)\to 1$，$i\in N$ 时 $\hat{s}_i/s_i(\mu_k)\to 1$，其余项为零，于是

$$|B|+|N|=n.$$

互补性 $\hat{\boldsymbol{x}}^{\top}\hat{\boldsymbol{s}}=0$ 说明 $B\cap N=\varnothing$，所以它们的并集是全部下标。

极限唯一。由上一步，任何聚点的正分量位置都包含任何最优解的正分量位置，所以所有聚点有相同的 B 和 N，任何原始最优解在 N 上为零。在式 (4.14)中取 $\boldsymbol{s}^{\star}=\hat{\boldsymbol{s}}$、$\boldsymbol{x}^{\star}$ 为任意原始最优解，令 $\mu_k\to 0$，得到

$$|N|+\sum_{i\in B}\frac{x_i^{\star}}{\hat{x}_i}=n,\qquad\text{即}\qquad\sum_{i\in B}\frac{x_i^{\star}-\hat{x}_i}{\hat{x}_i}=0.$$

4.1 中心路径
4.2 原始—对偶路径跟踪
4.3 初始点
4.4 求解精度
4.5 多项式复杂度
4.6 单纯形法与内点法的比较
4.7 本章小结

这正是凹函数 (4.12)在 $\hat{\boldsymbol{x}}$ 处沿任意最优面方向的方向导数为零，所以 $\hat{\boldsymbol{x}}$ 是它在最优面上的最大点。严格凹性保证最大点唯一，因此所有聚点的 $\boldsymbol{x}$ 部分相同。对 $\hat{\boldsymbol{s}}$ 同理，得到相应的 $\sum_{i\in N}\log s_i$ 最大的唯一点，再由 $\boldsymbol{A}^{\top}$ 列满秩，$\hat{\boldsymbol{y}}$ 也唯一。有界序列只有一个聚点，所以收敛。 ■

这个定理有两个直接的推论。最优解唯一时，路径通向顶点；最优解不唯一时，路径通向最优面的相对内部，得不到顶点。此外，定理顺带证明了线性规划在 $\mathcal{F}^{\circ}$ 非空时总有严格互补解。

这里的下标集 B 和单纯形法的基不是一回事：B 是极限点的正分量位置，可以多于或少于 m 个。内点法最终告诉我们的是“哪些变量为正”，而不是直接给出一个基，第 4.4节会处理两者的转换。

4.2 原始—对偶路径跟踪

上一节得到一条曲线，但求曲线上的一个点要解一组非线性方程。于是要问：不把每个中心点算准，怎样一步步沿曲线走向 $\mu=0$？做法是把三组条件当作一个方程组，同时更新 $\boldsymbol{x},\boldsymbol{y},\boldsymbol{s}$。

主要思想：对扰动方程作 Newton 线性化 当前点记为 $(\boldsymbol{x},\boldsymbol{y},\boldsymbol{s})$，只要求 $\boldsymbol{x},\boldsymbol{s}>\boldsymbol{0}$。为了同时适用下一节的不可行起点，这里不假设它满足等式约束。当前的平均互补量是

$$\mu=\frac{\boldsymbol{x}^{\top}\boldsymbol{s}}{n}. \tag{4.15}$$

我们不把目标定为 $\mu=0$，而定为路径上 $\sigma\mu$ 处的中心点，其中 $\sigma\in[0,1]$ 称为**中心化参数**（centering parameter）。这一轮想达到的是

$$\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b},\qquad \boldsymbol{A}^{\top}\boldsymbol{y}+\boldsymbol{s}=\boldsymbol{c},\qquad x_i s_i=\sigma\mu.$$

把新的点写成 $\boldsymbol{x}+\Delta\boldsymbol{x}$、$\boldsymbol{y}+\Delta\boldsymbol{y}$、$\boldsymbol{s}+\Delta\boldsymbol{s}$，代入这三组方程。前两组本身就是线性的，第三组展开是

$$x_i s_i + s_i\Delta x_i + x_i\Delta s_i + \Delta x_i\Delta s_i = \sigma\mu.$$

唯一的非线性项是 $\Delta x_i\Delta s_i$，它是两个小量的乘积。Newton 法的做法就是把它丢掉，留下关于方向的线性方程组。

为了写得紧凑，定义三个残差，分别度量原始等式、对偶等式和互补目标还差多少：

$$\boldsymbol{r}_{\mathrm{p}}=\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b},\qquad \boldsymbol{r}_{\mathrm{d}}=\boldsymbol{A}^{\top}\boldsymbol{y}+\boldsymbol{s}-\boldsymbol{c},\qquad \boldsymbol{r}_{\mathrm{c}}=\sigma\mu\boldsymbol{1}-\boldsymbol{X}\boldsymbol{S}\boldsymbol{1}, \tag{4.16}$$

其中 $\boldsymbol{S}=\operatorname{diag}(\boldsymbol{s})$。这样，方向 $(\Delta\boldsymbol{x},\Delta\boldsymbol{y},\Delta\boldsymbol{s})$ 由下面的线性方程组确定：

$$\begin{bmatrix} \boldsymbol{A} & \boldsymbol{0} & \boldsymbol{0} \\ \boldsymbol{0} & \boldsymbol{A}^{\top} & \boldsymbol{I} \\ \boldsymbol{S} & \boldsymbol{0} & \boldsymbol{X} \end{bmatrix} \begin{bmatrix} \Delta\boldsymbol{x} \\ \Delta\boldsymbol{y} \\ \Delta\boldsymbol{s} \end{bmatrix} = \begin{bmatrix} -\boldsymbol{r}_{\mathrm{p}} \\ -\boldsymbol{r}_{\mathrm{d}} \\ \boldsymbol{r}_{\mathrm{c}} \end{bmatrix}. \tag{4.17}$$

第一行要求走完之后原始残差消失，第二行要求对偶残差消失，第三行要求所有乘积都变成 $\sigma\mu$。系数矩阵正是三组方程关于 $(\boldsymbol{x},\boldsymbol{y},\boldsymbol{s})$ 的 Jacobian 矩阵。

为什么线性化 $x_is_i=\mu$，而不是 $s_i=\mu/x_i$　两种写法定义同一条曲线，线性化后的方程却差别很大。图 4.7取一个坐标，固定 $s=1$、$\mu=1$，方程的根是 $x=1$。图 (a) 对 $\mu/x-s=0$ 作 Newton 法，从 $x=2.4$ 出发，切线与横轴的交点落在 $x\approx-0.96$，越过了边界。

这件事不是偶然的。$1/x$ 在 x 大时很平，切线斜率过小，步子迈得过大；具体地，这个迭代是 $x\mapsto x(2-x)$，$x>2$ 时一步变成负数。图 (b) 对 $xs-\mu=0$ 作 Newton 法，函数本身关于 x 是直线，一步到根。一般情形中 s 也在变，方程对两个变量合起来是双线性的，但误差只是一个二阶小项 $\Delta x_i\Delta s_i$，线性模型“可信的范围”比倒数形式大得多。

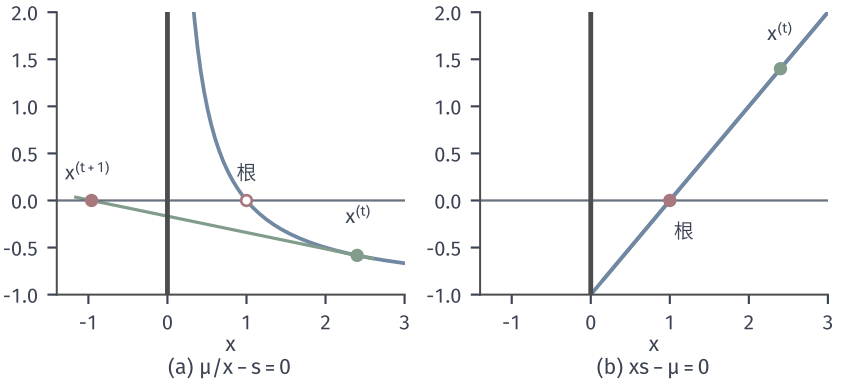


图 4.7　同一条约束的两种写法，$s=\mu=1$，根都是 $x=1$（红圈或红点）。(a) 蓝线是 $\mu/x-s$，绿线是在 $x^{(t)}=2.4$ 处的切线，Newton 步落到 $x^{(t+1)}\approx-0.96$（红点），越过边界（深灰粗线）。(b) 蓝线是 $xs-\mu$，本身就是直线，Newton 步一步到根。

消元：把方程组化成一个 $m\times m$ 的问题　方程组 (4.17)的大小是 $2n+m$，但结构很特殊，可以依次消元。由第二行，

$$\Delta\boldsymbol{s}=-\boldsymbol{r}_{\mathrm{d}}-\boldsymbol{A}^{\top}\Delta\boldsymbol{y}. \tag{4.18}$$

第三行是 $\boldsymbol{S}$ 与 $\boldsymbol{X}$ 两个对角矩阵分别作用在两个方向上，直接解出

$$\Delta\boldsymbol{x}=\boldsymbol{S}^{-1}\bigl(\boldsymbol{r}_{\mathrm{c}}-\boldsymbol{X}\Delta\boldsymbol{s}\bigr). \tag{4.19}$$

把式 (4.18)代入式 (4.19)，得到

$$\Delta \boldsymbol{x} = \boldsymbol{S}^{-1}\big(\boldsymbol{r}_{\mathrm{c}} + \boldsymbol{X}\boldsymbol{r}_{\mathrm{d}}\big) + \boldsymbol{S}^{-1}\boldsymbol{X}\boldsymbol{A}^{\top}\Delta \boldsymbol{y}.$$

记对角矩阵 $\boldsymbol{D} = \boldsymbol{X}\boldsymbol{S}^{-1}$，它的对角元是 x_i/s_i。把上式代入第一行 $\boldsymbol{A}\Delta\boldsymbol{x} = -\boldsymbol{r}_{\mathrm{p}}$，就得到只含 $\Delta\boldsymbol{y}$ 的方程。定义

$$\boldsymbol{M} = \boldsymbol{A}\boldsymbol{D}\boldsymbol{A}^{\top}, \qquad \boldsymbol{h} = -\boldsymbol{r}_{\mathrm{p}} - \boldsymbol{A}\boldsymbol{S}^{-1}\big(\boldsymbol{r}_{\mathrm{c}} + \boldsymbol{X}\boldsymbol{r}_{\mathrm{d}}\big), \tag{4.20}$$

方向 $\Delta\boldsymbol{y}$ 由下式给出：

$$\Delta \boldsymbol{y} = \boldsymbol{M}^{-1}\boldsymbol{h}. \tag{4.21}$$

$\boldsymbol{M}\Delta\boldsymbol{y} = \boldsymbol{h}$ 称为**正规方程**（normal equations），实际计算中用 Cholesky 分解求解，不显式求逆。求出 $\Delta\boldsymbol{y}$ 后，由式 (4.18)得到 $\Delta\boldsymbol{s}$，再由式 (4.19)得到 $\Delta\boldsymbol{x}$。

这一步之所以总能进行，靠的是下面的事实。

引理 4.6　Newton 方程可解　设 $\boldsymbol{A}$ 满行秩，$\boldsymbol{x}, \boldsymbol{s} > \boldsymbol{0}$。则 $\boldsymbol{M} = \boldsymbol{A}\boldsymbol{D}\boldsymbol{A}^{\top}$ 对称正定，方程组 (4.17)有唯一解，由式 (4.21)、(4.18)、(4.19)给出。

证明　$\boldsymbol{D}$ 的对角元全为正。对任何 $\boldsymbol{v} \neq \boldsymbol{0}$，$\boldsymbol{A}$ 满行秩给出 $\boldsymbol{A}^{\top}\boldsymbol{v} \neq \boldsymbol{0}$，于是

$$\boldsymbol{v}^{\top}\boldsymbol{M}\boldsymbol{v} = (\boldsymbol{A}^{\top}\boldsymbol{v})^{\top}\boldsymbol{D}(\boldsymbol{A}^{\top}\boldsymbol{v}) > 0,$$

所以 $\boldsymbol{M}$ 正定。上面的消元每一步都是等价变形，故方程组的解恰好由这三个公式给出。 ■

一步之后三个残差怎样变　设步长为 $\alpha \in (0, 1]$，$\boldsymbol{x}^{+} = \boldsymbol{x} + \alpha\Delta\boldsymbol{x}$，$\boldsymbol{y}^{+}$、$\boldsymbol{s}^{+}$ 同理。前两组方程是线性的，把第一行、第二行代入，新的残差就是

$$\boldsymbol{r}_{\mathrm{p}}^{+} = (1-\alpha)\boldsymbol{r}_{\mathrm{p}}, \qquad \boldsymbol{r}_{\mathrm{d}}^{+} = (1-\alpha)\boldsymbol{r}_{\mathrm{d}}. \tag{4.22}$$

走完单位步（$\alpha = 1$）时，等式残差恰好为零，此后一直为零。

互补量的变化由展开式得到。把 $\boldsymbol{x}^{+}$、$\boldsymbol{s}^{+}$ 代入内积，一次项由第三行给出

$$\boldsymbol{s}^{\top}\Delta\boldsymbol{x} + \boldsymbol{x}^{\top}\Delta\boldsymbol{s} = \boldsymbol{1}^{\top}\boldsymbol{r}_{\mathrm{c}} = n\sigma\mu - n\mu,$$

于是

$$(\boldsymbol{x}^{+})^{\top}\boldsymbol{s}^{+} = \big(1 - \alpha(1-\sigma)\big)\boldsymbol{x}^{\top}\boldsymbol{s} + \alpha^{2}\,\Delta\boldsymbol{x}^{\top}\Delta\boldsymbol{s}. \tag{4.23}$$

当前点严格可行时，两个等式残差为零，第一行和第二行给出

$$\boldsymbol{A}\Delta\boldsymbol{x} = \boldsymbol{0}, \qquad \Delta\boldsymbol{s} = -\boldsymbol{A}^{\top}\Delta\boldsymbol{y}.$$

所以 $\Delta\boldsymbol{x}^{\top}\Delta\boldsymbol{s} = 0$，互补量精确地按因子 $1-\alpha(1-\sigma)$ 下降。

步长：到边界的比例　Newton 方向可能把某个分量推成负数，所以步长要受限。沿方向走时，每个正分量到零的距离是确定的。定义能保持非负的最大步长

$$\alpha_{\max} = \min\Big\{\min_{\Delta x_i<0} \frac{x_i}{-\Delta x_i},\ \min_{\Delta s_i<0} \frac{s_i}{-\Delta s_i}\Big\}, \tag{4.24}$$

没有负分量时约定 $\alpha_{\max} = +\infty$。这个量和单纯形法的比值检验是同一种计算，只是后者走到恰好有一个变量为零，这里不能走到那么远，否则下一轮的 $\boldsymbol{S}^{-1}$ 或 $\boldsymbol{D}$ 不存在。

取一个略小于 1 的比例 η，例如 0.9 或 0.995，令

$$\alpha = \min\{1,\ \eta\,\alpha_{\max}\}, \tag{4.25}$$

这称为**到边界的比例规则**（fraction-to-the-boundary rule）。图 4.8是贯穿例第一轮的情形：六个坐标沿方向变化，其中 s_1 最先降到零，$\alpha_{\max}$ 由它决定。

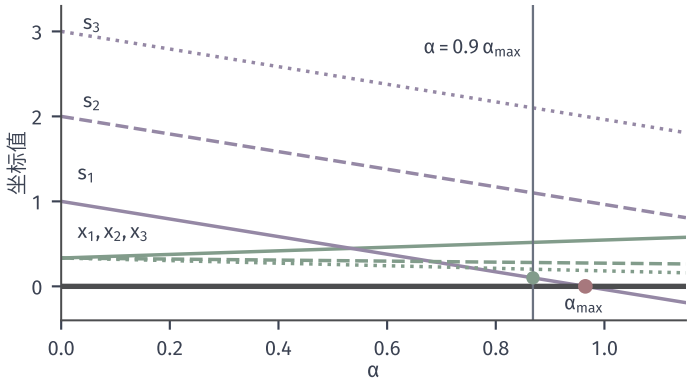


图 4.8　贯穿例第一轮各坐标沿 Newton 方向的变化，$\sigma = 0.3$。紫线是 s_1, s_2, s_3，绿线是 x_1, x_2, x_3，实线、虚线、点线依次对应下标 $1, 2, 3$，深灰粗线是边界。s_1 在 $\alpha_{\max} = 55/57 \approx 0.965$ 处最先到达零（红点），取 $\eta = 0.9$ 后实际步长 $\alpha = 33/38 \approx 0.868$（竖线与绿点）。

中心化：两种力量的折中　参数 σ 控制这一轮更想做什么。$\sigma = 1$ 时目标是当前 μ 处的中心点，方向只把点拉回路径，互补量不减；$\sigma = 0$ 时目标直接是 $\mu = 0$，这个方向称为**仿射尺度方向**（affine-scaling direction），只求减小互补量，不管中心性。

可以把中心路径想成山谷的谷线，互补量是海拔。$\sigma=0$ 相当于只顾朝谷底方向走，容易撞上谷壁，步长被迫很小。$\sigma=1$ 相当于退回谷线，位置好了，海拔没降。合适的 σ 介于两者之间，类比的失效之处是，这里“谷壁”是 x_i 或 s_i 接近零的边界，不是某个目标函数的等高线。

计算过程 下面把每一轮写成具体步骤，并在例 (4.5)上逐轮计算。取固定的中心化参数 $\sigma=0.3$、比例 $\eta=0.9$，容差 $\varepsilon=10^{-3}$，起点选严格可行点。

变量

- $\boldsymbol{x}\in\mathbb{R}^n$：当前原始点，所有分量为正。
- $\boldsymbol{y}\in\mathbb{R}^m$：当前对偶变量。
- $\boldsymbol{s}\in\mathbb{R}^n$：当前对偶松弛，所有分量为正。
- μ：当前平均互补量，由式 (4.15)计算。
- $\boldsymbol{r}_{\mathrm{p}},\boldsymbol{r}_{\mathrm{d}},\boldsymbol{r}_{\mathrm{c}}$：式 (4.16)的三个残差，形状分别是 m、n、n 维。
- $\boldsymbol{D}$、$\boldsymbol{M}$、$\boldsymbol{h}$：对角缩放矩阵、$m\times m$ 的正规矩阵和右端，由式 (4.20)计算。
- $\Delta\boldsymbol{x},\Delta\boldsymbol{y},\Delta\boldsymbol{s}$：本轮的方向，$\alpha_{\max},\alpha$ 是最大步长和实际步长。

初始化 取严格可行的起点 $(\boldsymbol{x}^{(0)},\boldsymbol{y}^{(0)},\boldsymbol{s}^{(0)})\in\mathcal{F}^\circ$，令 $t=0$；起点怎样得到由下一节回答。例中取

$$\boldsymbol{x}^{(0)}=\Big(\frac{1}{3},\frac{1}{3},\frac{1}{3}\Big)^{\top},\qquad y^{(0)}=0,\qquad \boldsymbol{s}^{(0)}=(1,2,3)^{\top}.$$

它满足等式约束，但不是中心点：三个乘积分别是 $1/3$、$2/3$、1。

每轮更新 在第 t 轮，以 $(\boldsymbol{x}^{(t)},\boldsymbol{y}^{(t)},\boldsymbol{s}^{(t)})$ 为当前点：

1. **检查停止**。按式 (4.16)计算 $\boldsymbol{r}_{\mathrm{p}}$、$\boldsymbol{r}_{\mathrm{d}}$，按式 (4.15)计算 $\mu^{(t)}$。若等式残差和互补量都不超过容差，停止并输出当前点。

   例中第一轮

   $$\mu^{(0)}=\frac{1}{3}\Big(\frac{1}{3}+\frac{2}{3}+1\Big)=\frac{2}{3},\qquad \boldsymbol{x}^{\top}\boldsymbol{s}=2>\varepsilon,$$

   等式残差都是零，继续。

2. **计算互补残差**。按式 (4.16)计算 $\boldsymbol{r}_{\mathrm{c}}$，这里的 μ 取 $\mu^{(t)}$。

   例中第一轮 $\sigma\mu^{(0)}=1/5$，

   $$\boldsymbol{r}_{\mathrm{c}}=\frac{1}{5}\mathbf{1}-\Big(\frac{1}{3},\frac{2}{3},1\Big)^{\top}=\Big(-\frac{2}{15},-\frac{7}{15},-\frac{4}{5}\Big)^{\top}.$$

3. **形成并求解正规方程**。由式 (4.20)计算 $\boldsymbol{M}$ 和 $\boldsymbol{h}$，由式 (4.21)得到 $\Delta\boldsymbol{y}$。

   例中 $\boldsymbol{r}_{\mathrm{p}}, \boldsymbol{r}_{\mathrm{d}}$ 为零，$\boldsymbol{D}$ 的对角元是 x_i/s_i，$\boldsymbol{A}$ 是一行全一，所以 $\boldsymbol{M}$ 和 $\boldsymbol{h}$ 都是数。第一轮

   $$M = \frac{1}{3} + \frac{1}{6} + \frac{1}{9} = \frac{11}{18}, \qquad h = -\sum_{i=1}^{3} \frac{r_{\mathrm{c},i}}{s_i} = \frac{2}{15} + \frac{7}{30} + \frac{4}{15} = \frac{19}{30},$$

   于是

   $$\Delta y = \frac{19/30}{11/18} = \frac{57}{55} \approx 1.0364.$$

4. **回代方向**。由式 (4.18)得到 $\Delta\boldsymbol{s}$，由式 (4.19)得到 $\Delta\boldsymbol{x}$。

   例中第一轮 $\Delta\boldsymbol{s} = -\Delta y\mathbf{1}$，$\Delta x_i = (r_{\mathrm{c},i} - x_i \Delta s_i)/s_i$，于是

   $$\Delta\boldsymbol{s} = -\frac{57}{55}\mathbf{1}, \qquad \Delta\boldsymbol{x} = \left(\frac{7}{33}, -\frac{2}{33}, -\frac{5}{33}\right)^{\mathsf{T}}.$$

   三个 Δx_i 相加为零，这正是 $\boldsymbol{A}\Delta\boldsymbol{x} = \mathbf{0}$。

5. **确定步长**。由式 (4.24)、(4.25)计算 $\alpha_{\max}$ 和 α。

   例中第一轮三个 s_i 的比值分别是 $\frac{55}{57}, \frac{110}{57}, \frac{165}{57}$，$x_2, x_3$ 的比值分别是 $\frac{11}{2}, \frac{11}{5}$，最小的是 s_1 的比值，所以

   $$\alpha_{\max} = \frac{55}{57} \approx 0.9649, \qquad \alpha = \frac{9}{10} \cdot \frac{55}{57} = \frac{33}{38} \approx 0.8684.$$

6. **更新**。令

   $$\begin{aligned} \boldsymbol{x}^{(t+1)} &= \boldsymbol{x}^{(t)} + \alpha\Delta\boldsymbol{x}, \\ \boldsymbol{y}^{(t+1)} &= \boldsymbol{y}^{(t)} + \alpha\Delta\boldsymbol{y}, \\ \boldsymbol{s}^{(t+1)} &= \boldsymbol{s}^{(t)} + \alpha\Delta\boldsymbol{s}, \end{aligned} \tag{4.26}$$

   然后令 $t \leftarrow t+1$，回到第 1 步。这里原始变量和对偶变量用同一个步长，式 (4.23)的精确下降公式依赖这一点。

   例中第一轮

   $$\boldsymbol{x}^{(1)} = \left(\frac{59}{114}, \frac{16}{57}, \frac{23}{114}\right)^{\mathsf{T}} \approx (0.5175, 0.2807, 0.2018)^{\mathsf{T}},$$

   对偶部分是

   $$y^{(1)} = \frac{9}{10}, \qquad \boldsymbol{s}^{(1)} = \left(\frac{1}{10}, \frac{11}{10}, \frac{21}{10}\right)^{\mathsf{T}}.$$

   按式 (4.23)，互补量应是

   $$\left(1 - \frac{33}{38} \cdot \frac{7}{10}\right) \cdot 2 = \frac{149}{190} \approx 0.7842.$$

   直接计算 $\sum_i x_i^{(1)} s_i^{(1)}$ 也得到这个数。

三个乘积这时是 $(0.0518, 0.3088, 0.4237)$，差距比起点时大了，这一步以中心性为代价换来了较长的步子。

例中第二轮的中间量如下。当前 $\mu^{(1)} = 0.2614$，$\sigma\mu^{(1)} = 0.07842$，

$$\boldsymbol{r}_{\mathrm{c}} = (0.0267, -0.2304, -0.3453)^{\top},$$
$$\boldsymbol{D} = \operatorname{diag}(5.1754, 0.2552, 0.0961).$$

第一个分量已经被压低，$x_1 s_1$ 小于目标 $\sigma\mu$，所以 $r_{\mathrm{c},1}$ 变成正的，这一轮要把它往上拉。

正规方程给出

$$M = 5.5267, \qquad h = 0.1072, \qquad \Delta y = 0.0194.$$

回代得到

$$\Delta \boldsymbol{s} = -0.0194\,\mathbf{1}, \qquad \Delta \boldsymbol{x} = (0.3670, -0.2045, -0.1625)^{\top}.$$

这一轮 $\alpha_{\max} = 1.2412$，$0.9\alpha_{\max} > 1$，所以取 $\alpha = 1$，于是

$$\boldsymbol{x}^{(2)} = (0.8846, 0.0762, 0.0392)^{\top}, \qquad y^{(2)} = 0.9194,$$
$$\boldsymbol{s}^{(2)} = (0.0806, 1.0806, 2.0806)^{\top}.$$

互补量精确地变为 $0.3 \times 0.7842 = 0.2353$。

此后每轮都取 $\alpha = 1$，互补量每轮乘以 0.3。表 4.1列出全部 7 轮的中间量。第 7 轮后互补量约为 5.7×10^{-4}，不超过 ε，算法停止。

t	$x_1^{(t)}$	$x_2^{(t)}$	$y^{(t)}$	$\mu^{(t)}$	M	Δy	$\alpha_{\max}$	α
0	0.3333	0.3333	0	0.6667	0.6111	1.0364	0.9649	0.8684
1	0.5175	0.2807	0.9	0.2614	5.527	0.0194	1.2412	1
2	0.8846	0.0762	0.9194	0.0784	11.06	0.0610	1.3210	1
3	0.9615	0.0261	0.9804	0.0235	49.12	0.0128	1.3851	1
4	0.9892	0.0073	0.9932	0.0071	146.0	0.0047	1.4179	1
5	0.9968	0.0021	0.9979	0.0021	477.3	0.0015	1.4247	1
6	0.9990	0.0006	0.9994	0.0006	1579	0.0004	1.4274	1
7	0.9997	0.0002	0.9998	0.0002				

表 4.1　贯穿例的逐轮中间量，$\sigma = 0.3$、$\eta = 0.9$。$x_3^{(t)} = 1 - x_1^{(t)} - x_2^{(t)}$，$s_i^{(t)} = c_i - y^{(t)}$。第 t 行的 $M, \Delta y, \alpha_{\max}, \alpha$ 是从第 t 个点出发那一轮的量。

最终得到

$$\hat{\boldsymbol{x}} \approx (0.9997, 0.0002, 0.0001)^{\top}, \qquad \hat{y} \approx 0.9998,$$

互补量约 5.7×10^{-4}，目标值 $\boldsymbol{c}^{\mathsf{T}}\hat{\boldsymbol{x}}\approx 1.0004$。由于迭代全程可行，间隙就是互补量，目标误差不超过 5.7×10^{-4}。实际误差约 3.8×10^{-4}，确实在这个界内。这里的 $\hat{\boldsymbol{x}}$ 不是顶点，第 4.4节讨论这一点的影响。

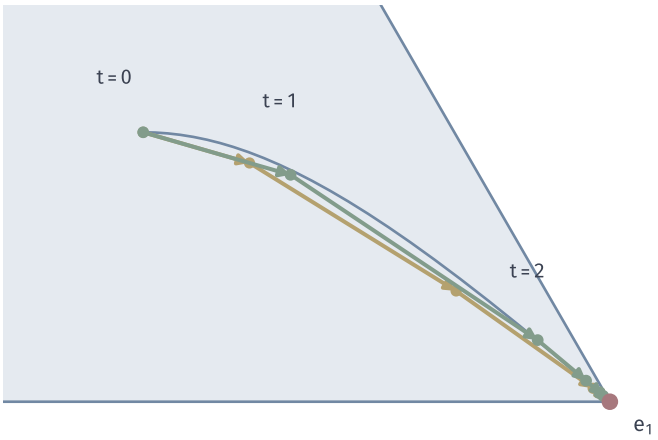


图 4.9　贯穿例的迭代点，三角形局部放大。蓝线是中心路径，绿色是 $\sigma=0.3$ 的路径跟踪，黄色是更激进的 $\sigma=0.1$，红点是最优顶点 $\boldsymbol{e}_1$。迭代点不在路径上，而是绕在路径附近前进。

σ 的取值　图 4.9中迭代点没有贴着路径，但始终在它附近。这种“附近”的程度可以用 $\min_i x_i s_i/\mu$ 度量，它等于 1 时点是中心点，接近 0 时某个乘积远低于平均。

图 4.10比较了不同的 σ。图 (a) 中，σ 越小，互补量下降越快，但这只是因为每轮的目标更激进。图 (b) 说明了代价：$\sigma=0.1$ 前两轮的步长只有 0.63 和 0.68，到 $t=2$ 时中心性掉到 0.07 左右，靠后面的几轮才恢复。$\sigma=0.9$ 则一直很靠近中心，下降却极慢。

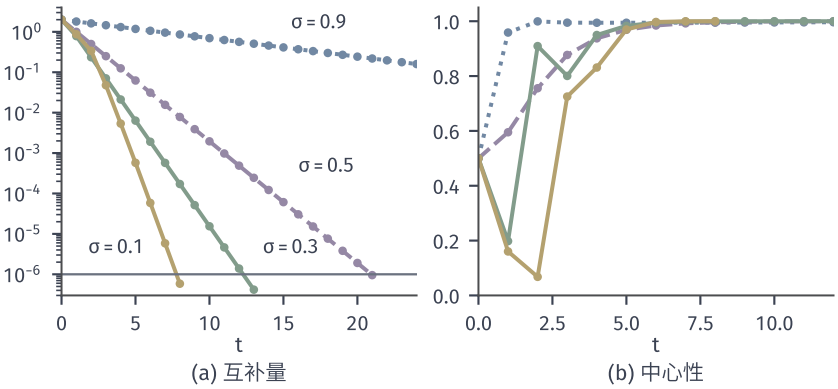


图 4.10　中心化参数的影响，贯穿例，$\eta=0.9$。(a) 互补量 $\boldsymbol{x}^{\mathsf{T}}\boldsymbol{s}$ 随轮次的变化，灰色横线是 10^{-6}。(b) 中心性 $\min_i x_i s_i/\mu$，等于 1 表示恰好在中心路径上。绿线 $\sigma=0.3$，黄线 $\sigma=0.1$，紫色虚线 $\sigma=0.5$，蓝色点线 $\sigma=0.9$。

预测—校正：先试走一步 固定的 σ 有两个缺点：它不知道这一轮能走多远，也没有处理被丢掉的二阶项 $\Delta x_i \Delta s_i$。**预测—校正**（predictor-corrector）方法用一次试算解决这两件事，额外代价只是多解一次已经分解好的方程组。

预测是先解一次 $\sigma = 0$ 的方程组，得到仿射尺度方向 $(\Delta \boldsymbol{x}^{\mathrm{a}}, \Delta \boldsymbol{y}^{\mathrm{a}}, \Delta \boldsymbol{s}^{\mathrm{a}})$，也就是令 $\boldsymbol{r}_{\mathrm{c}} = -\boldsymbol{X}\boldsymbol{S}\mathbf{1}$。沿它能走的步长记为 α^{a}，试走之后的平均互补量是

$$\mu^{\mathrm{a}} = \frac{(\boldsymbol{x} + \alpha^{\mathrm{a}} \Delta \boldsymbol{x}^{\mathrm{a}})^{\top} (\boldsymbol{s} + \alpha^{\mathrm{a}} \Delta \boldsymbol{s}^{\mathrm{a}})}{n}. \tag{4.27}$$

这个数说明当前点有多好走：μ^{a} 远小于 μ 时，纯下降方向很有效，不需要多少中心化。常用的选法是

$$\sigma = \left(\frac{\mu^{\mathrm{a}}}{\mu} \right)^{3}. \tag{4.28}$$

三次方是一条经验规则，没有理论上的必然性。

校正处理二阶项。式 (4.17)假装 $\Delta x_i \Delta s_i = 0$，预测步已经给出了这一项的估计 $\Delta x_i^{\mathrm{a}} \Delta s_i^{\mathrm{a}}$，于是把它移到右端：

$$\boldsymbol{r}_{\mathrm{c}} = \sigma \mu \mathbf{1} - \boldsymbol{X}\boldsymbol{S}\mathbf{1} - \Delta \boldsymbol{X}^{\mathrm{a}} \Delta \boldsymbol{S}^{\mathrm{a}} \mathbf{1}. \tag{4.29}$$

用这个 $\boldsymbol{r}_{\mathrm{c}}$ 按式 (4.20)至(4.19)求方向，步长仍按式 (4.25)。两次求解的系数矩阵 $\boldsymbol{M}$ 相同，所以只分解一次，这一点在 $\boldsymbol{M}$ 很大时决定了这个方法的价值。

例中第一轮，预测方向取 $\sigma = 0$，M 与前面相同，右端变成 $h = 1$，得到

$$\Delta y^{\mathrm{a}} = \frac{18}{11}, \qquad \Delta \boldsymbol{x}^{\mathrm{a}} = \left(\frac{7}{33}, -\frac{2}{33}, -\frac{5}{33} \right)^{\top}.$$

这里 $\Delta \boldsymbol{x}^{\mathrm{a}}$ 与固定 $\sigma = 0.3$ 时相同，是因为起点是三角形的解析中心，中心化分量在 $\boldsymbol{x}$ 上恰好为零。

步长由 s_1 决定，试走后的互补量和中心化参数是

$$\alpha^{\mathrm{a}} = \frac{11}{18}, \qquad \mu^{\mathrm{a}} = \frac{7}{27} \approx 0.2593, \qquad \sigma = \left(\frac{7}{18} \right)^{3} \approx 0.0588.$$

校正的右端由式 (4.29)算出，其中 $\sigma\mu \approx 0.0392$，二阶项的估计是

$$\Delta \boldsymbol{X}^{\mathrm{a}} \Delta \boldsymbol{S}^{\mathrm{a}} \mathbf{1} \approx (-0.3471, 0.0992, 0.2479)^{\top},$$

于是

$$\boldsymbol{r}_{\mathrm{c}} \approx (0.0530, -0.7266, -1.2087)^{\top}, \qquad h \approx 0.7132, \qquad \Delta y \approx 1.1671.$$

4.1 中心路径
4.2 原始—对偶路径跟踪
4.3 初始点
4.4 求解精度
4.5 多项式复杂度
4.6 单纯形法与内点法的比较
4.7 本章小结

这一步的最大步长是 $\alpha_{\max} \approx 0.8568$，取 $\alpha \approx 0.7711$，得到

$$\boldsymbol{x}^{(1)} \approx (0.6742, 0.2032, 0.1226)^{\mathsf{T}}, \qquad y^{(1)} = 0.9, \qquad \boldsymbol{x}^{\mathsf{T}}\boldsymbol{s} \approx 0.5485.$$

相比之下，固定 $\sigma = 0.3$ 第一轮后的互补量是 0.7842。

图 4.11(a) 显示了校正的作用。黄色柱是单位预测步之后的乘积，第一个分量甚至为负，也就是说走完单位步会越界。绿色柱是校正后的单位步，三个乘积都向目标 $\sigma\mu$ 靠拢，虽然这一轮离路径较远，并没有完全到位。

图 (b) 显示，整体上预测—校正用 7 轮把互补量降到 10^{-6} 以下，固定 $\sigma = 0.3$ 用 13 轮。需要说明，这是这个小例子上的观察，式 (4.28)没有迭代次数的一般保证。

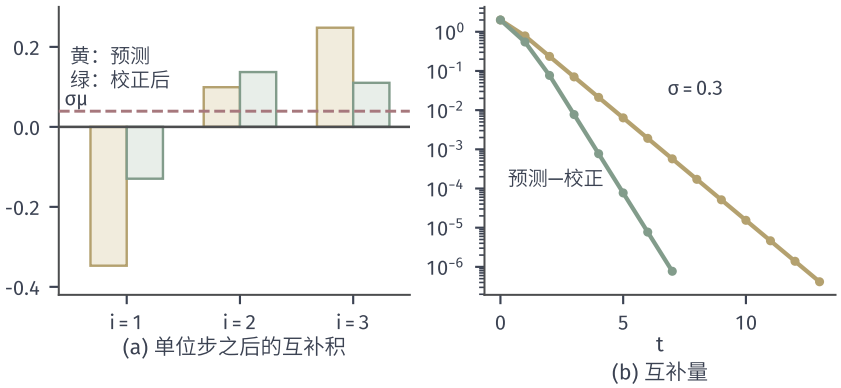


图 4.11 预测—校正的效果，贯穿例。(a) 从起点走单位步之后三个乘积 $x_i s_i$ 的值：黄色为预测方向，绿色为校正后方向，红色虚线是目标 $\sigma\mu \approx 0.039$。(b) 互补量随轮次的变化，绿线为预测—校正，黄线为固定 $\sigma = 0.3$，两者都取 $\eta = 0.9$，容差为 10^{-6}。

计算代价 每轮的主要工作是形成 $\boldsymbol{M} = \boldsymbol{A}\boldsymbol{D}\boldsymbol{A}^{\mathsf{T}}$ 并作 Cholesky 分解。稠密情形下，形成 $\boldsymbol{M}$ 需要约 $m^2 n$ 次运算，分解需要约 $m^3/3$ 次运算；稀疏情形下取决于分解的填充，第 4.6节再详细讨论。

$\boldsymbol{M}$ 的非零模式只由 $\boldsymbol{A}$ 决定，每轮只有 $\boldsymbol{D}$ 的数值在变，所以分解的符号结构只需分析一次。回代得到 $\Delta\boldsymbol{s}$ 和 $\Delta\boldsymbol{x}$ 的代价相对可以忽略。

4.3 初始点

上一节的计算从一个严格可行点出发。贯穿例的约束很简单，这样的点一眼可见，一般问题却未必。接下来要弄清：起点从哪里来，起点不可行时算法还能不能用，问题本身没有严格可行点时又该怎么办？

可行初始方法 最直接的想法是先求出一个严格可行点，再开始路径跟踪，这和单纯形法的第一阶段是同一个思路。对原始一侧，构造辅助问题

$$\min_{\boldsymbol{x},\rho}\ \rho \quad \text{s.t.} \quad \boldsymbol{A}\boldsymbol{x}=\boldsymbol{b},\quad \boldsymbol{x}+\rho\mathbf{1}\ge\mathbf{0},\quad \rho\ge -1. \tag{4.30}$$

ρ 越小，$\boldsymbol{x}$ 离边界越有余量。下界 -1 只是为了防止 ρ 在可行集无界时下降到负无穷。

这个辅助问题的严格可行点是现成的：任取 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 的一个解，例如最小范数解 $\boldsymbol{A}^{\top}(\boldsymbol{A}\boldsymbol{A}^{\top})^{-1}\boldsymbol{b}$，再取足够大的 ρ 即可。最优值 $\rho^{\star}$ 的符号给出三种结论：

- $\rho^{\star}<0$：最优点满足 $x_i\ge -\rho^{\star}>0$，这是原问题的严格可行点。
- $\rho^{\star}=0$：原问题可行，但没有严格可行点。
- $\rho^{\star}>0$：原问题不可行。

三种情形可以用同一个小例子看到。取两个变量和约束 $x_1+x_2=a$。把两个分量约束相加，得到 $a+2\rho\ge 0$，即 $\rho\ge -a/2$。取 $a=1$ 时，$\rho^{\star}=-1/2$，最优点 $(1/2,1/2)$ 严格可行。取 $a=0$ 时，$\rho^{\star}=0$，可行点只有原点。取 $a=-1$ 时，$\rho^{\star}=1/2$，原问题不可行。

这个方法有两点不足。辅助问题本身也是线性规划，且它的对偶一侧未必有严格可行点：只有不存在非零的 $\boldsymbol{d}\ge\mathbf{0}$ 使 $\boldsymbol{A}\boldsymbol{d}=\mathbf{0}$ 时才有，否则要先加上足够大的变量上界。另外，对偶一侧还要另解一个类似的问题，求出来的点也通常离中心路径很远，要用 σ 接近 1 的几步先作中心化。这些原因使大规模实现很少走这条路。

不可行初始方法 更常用的做法是放弃“起点满足等式”这个要求，只保持 $\boldsymbol{x},\boldsymbol{s}>\mathbf{0}$。方程组 (4.17)的右端本来就含 $\boldsymbol{r}_{\mathrm{p}}$ 和 $\boldsymbol{r}_{\mathrm{d}}$，上一节的公式可以原样使用。式 (4.22)说明，每走步长 α，两个等式残差都精确地乘以 $1-\alpha$。

这和可行初始方法的区别在于，等式约束不再是“先满足的前提”，而是和互补量一起逐步降低的目标。迭代点在走向最优的同时走向可行。

用贯穿例试算，起点取 $\boldsymbol{x}^{(0)}=\boldsymbol{s}^{(0)}=\mathbf{1}$、$y^{(0)}=0$，它不满足任何等式。残差是

$$r_{\mathrm{p}}=2,\qquad \boldsymbol{r}_{\mathrm{d}}=(0,-1,-2)^{\top},\qquad \mu^{(0)}=1.$$

取 $\sigma=0.3$，$\boldsymbol{r}_{\mathrm{c}}=-0.7\,\mathbf{1}$。

由式 (4.20)，$\boldsymbol{D}=\boldsymbol{I}$，于是

$$M=3,\qquad h=-2-\sum_{i=1}^{3}\bigl(r_{\mathrm{c},i}+r_{\mathrm{d},i}\bigr)=3.1,\qquad \Delta y=\frac{31}{30}\approx 1.0333.$$

回代得到

$$\Delta \boldsymbol{s} \approx (-1.0333, -0.0333, 0.9667)^{\top}, \qquad \Delta \boldsymbol{x} \approx (0.3333, -0.6667, -1.6667)^{\top}.$$

$\alpha_{\max} = 0.6$ 由 x_3 决定，取 $\alpha = 0.54$。新的残差恰好是原来的 0.46 倍，点是

$$\boldsymbol{x}^{(1)} = (1.18, 0.64, 0.10)^{\top}, \qquad y^{(1)} = 0.558, \qquad \boldsymbol{s}^{(1)} = (0.442, 0.982, 1.522)^{\top}.$$

可以核对 $r_{\mathrm{p}} = 1.92 - 1 = 0.92 = 0.46 \times 2$。

接下来第二轮取 $\alpha \approx 0.894$，第三轮取到 $\alpha = 1$，等式残差降到舍入误差水平，此后成为可行迭代，如图 4.12(a)。

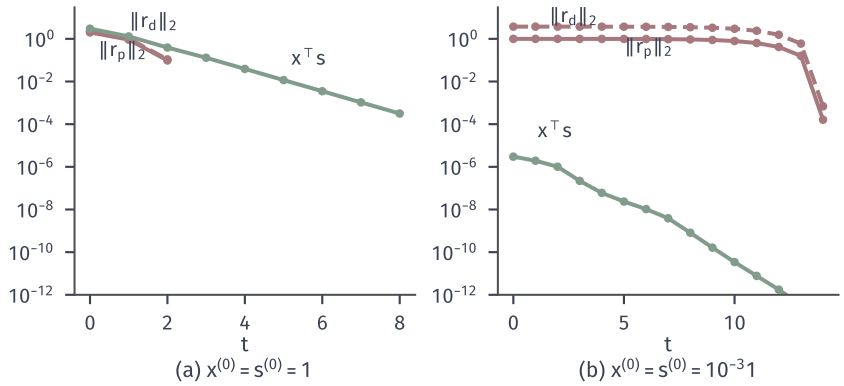


图 4.12 不可行起点的两种情况，贯穿例，$\sigma = 0.3$、$\eta = 0.9$，对数纵轴。红色实线是 $\|\boldsymbol{r}_{\mathrm{p}}\|_2$，红色虚线是 $\|\boldsymbol{r}_{\mathrm{d}}\|_2$，绿线是 $\boldsymbol{x}^{\top}\boldsymbol{s}$。(a) 起点 $\boldsymbol{x} = \boldsymbol{s} = \mathbf{1}$，残差在第 3 轮取单位步后归零（图中不再画出）。(b) 起点 $\boldsymbol{x} = \boldsymbol{s} = 10^{-3}\mathbf{1}$，互补量先极快地变小，而残差前十轮几乎不动，因为此间的步长只有 10^{-3} 到 10^{-1} 量级。

起点太小的后果 图 4.12(b) 把起点缩小到 $10^{-3}\mathbf{1}$。这个起点的互补量已经小到 3×10^{-6}，等式残差却仍有 1 和 3.7 的量级。起点小，意味着方程 $x_i s_i \approx \sigma\mu$ 的线性化只允许很小的移动：Newton 方向要消除大的等式残差，$\alpha_{\max}$ 却被很小的 x_i, s_i 限制，头几轮的步长只有约 7×10^{-4}。

算法最终还是走出来了，但这是这个例子的运气，不是一般保证。理论分析要求互补量不能比等式残差下降得快，常用的条件是

$$\frac{\|(\boldsymbol{r}_{\mathrm{p}}^{(t)}, \boldsymbol{r}_{\mathrm{d}}^{(t)})\|_2}{\mu^{(t)}} \le C \, \frac{\|(\boldsymbol{r}_{\mathrm{p}}^{(0)}, \boldsymbol{r}_{\mathrm{d}}^{(0)})\|_2}{\mu^{(0)}}, \tag{4.31}$$

其中 $C \ge 1$ 是常数，并且要求起点足够大。这种算法的全局收敛和复杂度结果需要较长的邻域分析，读者可查阅专著[1]。在实现中，它对应的经验是起点的 $\boldsymbol{x}$ 和 $\boldsymbol{s}$ 要足够大，互补量相对残差不能太小。

[1] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

一个常用的起点 起点要兼顾两件事：接近满足等式，以及各分量足够大。一个常用的启发式分两步。先求最小范数意义下的近似：

$$\tilde{\boldsymbol{x}} = \boldsymbol{A}^{\top}(\boldsymbol{A}\boldsymbol{A}^{\top})^{-1}\boldsymbol{b}, \qquad \tilde{\boldsymbol{y}} = (\boldsymbol{A}\boldsymbol{A}^{\top})^{-1}\boldsymbol{A}\boldsymbol{c}, \qquad \tilde{\boldsymbol{s}} = \boldsymbol{c} - \boldsymbol{A}^{\top}\tilde{\boldsymbol{y}}. \tag{4.32}$$

再把负分量和过小的分量整体平移成正的。贯穿例中 $\boldsymbol{A}\boldsymbol{A}^{\top} = 3$，于是 $\tilde{\boldsymbol{x}} = \frac{1}{3}\mathbf{1}$，$\tilde{y} = 2$，$\tilde{\boldsymbol{s}} = (-1, 0, 1)^{\top}$。

平移分两步。第一步取 $\delta_s = \max\{-1.5\min_i \tilde{s}_i, 0\} = 1.5$（$\tilde{\boldsymbol{x}}$ 已为正，$\delta_x = 0$），得到 $\hat{\boldsymbol{s}} = (0.5, 1.5, 2.5)^{\top}$。第二步按当前互补量再抬高一点，取

$$\hat{\delta}_x = \frac{1}{2}\frac{\tilde{\boldsymbol{x}}^{\top}\hat{\boldsymbol{s}}}{\mathbf{1}^{\top}\hat{\boldsymbol{s}}} = \frac{1}{6}, \qquad \hat{\delta}_s = \frac{1}{2}\frac{\tilde{\boldsymbol{x}}^{\top}\hat{\boldsymbol{s}}}{\mathbf{1}^{\top}\tilde{\boldsymbol{x}}} = \frac{3}{4}.$$

最后的起点是

$$\boldsymbol{x}^{(0)} = \frac{1}{2}\mathbf{1}, \qquad y^{(0)} = 2, \qquad \boldsymbol{s}^{(0)} = (1.25, 2.25, 3.25)^{\top}.$$

这是一条经验规则，没有理论保证，但在实践中通常能避开图 4.12(b) 的情形。

严格可行点不存在时 定理 4.2说明，$\mathcal{F}^{\circ}$ 为空时中心路径不存在，路径跟踪失去了依据。这种情况有两类来源，处理方式不同。

一类来自建模的表述，问题本身可解。典型例子是把无符号变量写成两个非负变量之差 $x = x^{+} - x^{-}$：两列互为相反数，第 4.1节的反例已经说明，这样的问题对偶一侧没有严格可行点。又如约束 $x_1 + x_2 = 0$ 强迫两个变量恒为零。

预处理（presolve）承担这类任务：删去冗余的行以恢复满行秩，把被约束确定的变量代入，识别恒为零的变量，单独处理自由变量，并把行列缩放到相近的量级。预处理不改变最优解集（或给出恢复原解的办法），却能去掉一大批使严格可行性失效的结构。

另一类是问题真的不可行或无界。这时算法的迭代通常会发散，互补量和残差都下不去，但“没有收敛”不等于“证明了不可行”。我们需要一种方法，在问题不可解时也能输出一张可以核对的证书。

齐次自对偶嵌入 思路是把原问题和对偶问题放进一个更大的、总有解的方程组里，用两个新的非负变量 τ, κ 来判别结局。**齐次模型**（homogeneous model）是

$$\begin{aligned} \boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\tau &= \mathbf{0}, \\ \boldsymbol{A}^{\top}\boldsymbol{y} + \boldsymbol{s} - \boldsymbol{c}\tau &= \mathbf{0}, \qquad \boldsymbol{x}, \boldsymbol{s} \geq \mathbf{0}, \quad \tau, \kappa \geq 0. \\ \boldsymbol{b}^{\top}\boldsymbol{y} - \boldsymbol{c}^{\top}\boldsymbol{x} - \kappa &= 0, \end{aligned} \tag{4.33}$$

零解总是满足它，所以这个模型不会没有解。不同的结局体现在非零解上：

- $\tau > 0$、$\kappa = 0$：把 $(\boldsymbol{x}, \boldsymbol{y}, \boldsymbol{s})$ 都除以 τ，前两行正是原始和对偶可行性，第三行说明目标相等，得到一对最优解。
- $\tau = 0$、$\kappa > 0$：此时 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{0}$，$\boldsymbol{A}^{\top}\boldsymbol{y} + \boldsymbol{s} = \boldsymbol{0}$，且 $\boldsymbol{b}^{\top}\boldsymbol{y} - \boldsymbol{c}^{\top}\boldsymbol{x} > 0$，所以 $\boldsymbol{b}^{\top}\boldsymbol{y} > 0$ 或 $\boldsymbol{c}^{\top}\boldsymbol{x} < 0$ 至少有一个成立。

后一种情况给出的正是不可行证书。若 $\boldsymbol{b}^{\top}\boldsymbol{y} > 0$，则原问题不可行：假如有 $\bar{\boldsymbol{x}} \geq \boldsymbol{0}$ 满足 $\boldsymbol{A}\bar{\boldsymbol{x}} = \boldsymbol{b}$，由 $\boldsymbol{A}^{\top}\boldsymbol{y} = -\boldsymbol{s}$，就有

$$\boldsymbol{b}^{\top}\boldsymbol{y} = \bar{\boldsymbol{x}}^{\top}\boldsymbol{A}^{\top}\boldsymbol{y} = -\bar{\boldsymbol{x}}^{\top}\boldsymbol{s} \leq 0,$$

与 $\boldsymbol{b}^{\top}\boldsymbol{y} > 0$ 矛盾。

若 $\boldsymbol{c}^{\top}\boldsymbol{x} < 0$，则对偶不可行：假如有 $(\bar{\boldsymbol{y}}, \bar{\boldsymbol{s}})$ 对偶可行，由 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{0}$，就有

$$\boldsymbol{c}^{\top}\boldsymbol{x} = \bar{\boldsymbol{s}}^{\top}\boldsymbol{x} + \bar{\boldsymbol{y}}^{\top}\boldsymbol{A}\boldsymbol{x} = \bar{\boldsymbol{s}}^{\top}\boldsymbol{x} \geq 0,$$

与 $\boldsymbol{c}^{\top}\boldsymbol{x} < 0$ 矛盾。

用一个不可行的小问题走一遍：$\min x$，约束 $x = -1$，$x \geq 0$。这里 $A = 1$，$b = -1$，$c = 1$，齐次模型是

$$x + \tau = 0, \qquad y + s - \tau = 0, \qquad -y - x - \kappa = 0.$$

第一式和非负性迫使 $x = \tau = 0$，第二式给出 $s = -y$，第三式给出 $\kappa = -y$。取 $y = -1$，得到解 $x = \tau = 0$、$s = \kappa = 1$。这时 $\kappa > 0$，$b\,y = 1 > 0$，正是原问题不可行的证书。

齐次模型的理论要点是：模型的系数矩阵是斜对称的，并且存在严格互补解，其中 τ 和 κ 恰有一个为正，所以结局一定是上面两种之一，原问题和对偶都不可行的情形归入后一种。式 (4.33)本身没有严格内点，实际的**齐次自对偶嵌入**（homogeneous self-dual embedding）再增加一个变量，构造出一个有明显严格内点、最优值为零的自对偶问题，于是路径跟踪可以从一个中心点直接开始。这一构造和收敛分析较长，读者可查阅专著的相关章节及其文献注记[2]。

图 4.13总结了三条路线各自解决的问题。贯穿例和工厂问题都走中间这条路线或第一条路线即可；需要可靠地判别不可行、无界时，第三条路线是目前的标准选择。

[2] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

4.1 中心路径
4.2 原始—对偶路径跟踪
4.3 初始点
4.4 求解精度
4.5 多项式复杂度
4.6 单纯形法与内点法的比较
4.7 本章小结

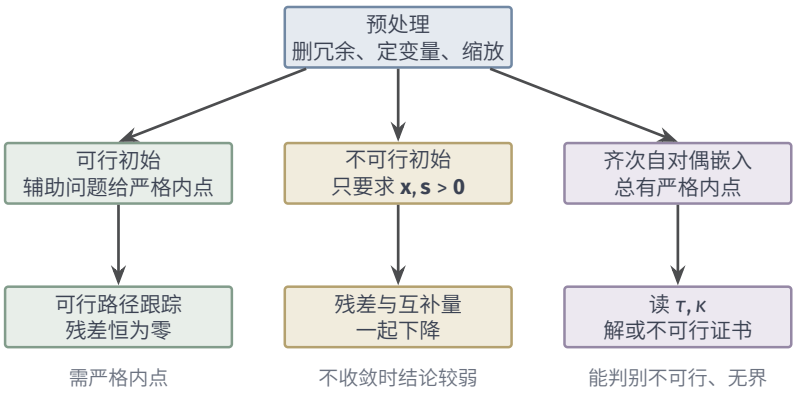


图 4.13 内点法起点的三条路线。预处理先去掉冗余和退化的结构。绿色路线先求严格可行点，迭代中残差恒为零；黄色路线只要求 $\boldsymbol{x},\boldsymbol{s}>\mathbf{0}$，等式残差与互补量同时下降；紫色路线把问题嵌入一个总有严格内点的模型，由 τ,κ 读出结局，并在问题不可解时给出证书。

4.4 求解精度

内点法的迭代点永远在内部，算法只能在某一步停下来。这就需要回答：什么时候可以停，停下来的点能说明什么，以及如果需要的不是近似解而是一个基、甚至一张严格的证书，还要做什么？

三项残差共同决定停止 一个点要接近最优，式 (4.4)的三组条件都要接近成立。通常用相对残差写成三条：

$$\frac{\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|_2}{1+\|\boldsymbol{b}\|_2}\le\varepsilon_{\mathrm{p}},\qquad \frac{\|\boldsymbol{A}^{\top}\boldsymbol{y}+\boldsymbol{s}-\boldsymbol{c}\|_2}{1+\|\boldsymbol{c}\|_2}\le\varepsilon_{\mathrm{d}},\qquad \frac{\boldsymbol{x}^{\top}\boldsymbol{s}}{1+|\boldsymbol{c}^{\top}\boldsymbol{x}|}\le\varepsilon_{\mathrm{g}}. \tag{4.34}$$

分母里的 1 防止右端或目标恰好接近零时的除零。这些容差的意义依赖数据的尺度：把一条约束乘以 1000，第一项的数值就改变，这和第 1章讨论可行性残差时指出的情况相同。

互补量何时是误差上界 式 (4.3)的恒等式依赖两侧都可行，这时结论是干净的。

定理 4.7 可行点上的误差界 设 $\boldsymbol{x}$ 原始可行，$(\boldsymbol{y},\boldsymbol{s})$ 对偶可行。则

$$0\le\boldsymbol{c}^{\top}\boldsymbol{x}-p^{\star}\le\boldsymbol{x}^{\top}\boldsymbol{s},\qquad 0\le d^{\star}-\boldsymbol{b}^{\top}\boldsymbol{y}\le\boldsymbol{x}^{\top}\boldsymbol{s}. \tag{4.35}$$

证明　$\boldsymbol{x}$ 可行给出 $\boldsymbol{c}^{\top}\boldsymbol{x} \geq p^{\star}$。由弱对偶 $\boldsymbol{b}^{\top}\boldsymbol{y} \leq d^{\star} \leq p^{\star}$，得到

$$\boldsymbol{c}^{\top}\boldsymbol{x} - p^{\star} \leq \boldsymbol{c}^{\top}\boldsymbol{x} - \boldsymbol{b}^{\top}\boldsymbol{y} = \boldsymbol{x}^{\top}\boldsymbol{s}.$$

第二式同理，用 $\boldsymbol{c}^{\top}\boldsymbol{x} \geq p^{\star} \geq d^{\star}$。 ■

两侧不可行时，这个界不再成立。此时

$$\boldsymbol{c} = \boldsymbol{A}^{\top}\boldsymbol{y} + \boldsymbol{s} - \boldsymbol{r}_{\mathrm{d}}, \qquad \boldsymbol{b} = \boldsymbol{A}\boldsymbol{x} - \boldsymbol{r}_{\mathrm{p}}.$$

代入目标差并整理，得到

$$\boldsymbol{c}^{\top}\boldsymbol{x} - \boldsymbol{b}^{\top}\boldsymbol{y} = \boldsymbol{x}^{\top}\boldsymbol{s} - \boldsymbol{r}_{\mathrm{d}}^{\top}\boldsymbol{x} + \boldsymbol{r}_{\mathrm{p}}^{\top}\boldsymbol{y}. \tag{4.36}$$

后两项的大小取决于残差和 $\boldsymbol{x}, \boldsymbol{y}$ 的大小。对目标误差有下面的两侧估计，它说明“残差小”换算成“目标差小”要付出什么。设 $(\boldsymbol{x}^{\star}, \boldsymbol{y}^{\star}, \boldsymbol{s}^{\star})$ 是一对最优解。

由 $\boldsymbol{c} = \boldsymbol{A}^{\top}\boldsymbol{y}^{\star} + \boldsymbol{s}^{\star}$ 和 $\boldsymbol{b}^{\top}\boldsymbol{y}^{\star} = p^{\star}$，直接计算得到

$$\boldsymbol{c}^{\top}\boldsymbol{x} - p^{\star} = (\boldsymbol{y}^{\star})^{\top}\boldsymbol{r}_{\mathrm{p}} + (\boldsymbol{s}^{\star})^{\top}\boldsymbol{x} \geq (\boldsymbol{y}^{\star})^{\top}\boldsymbol{r}_{\mathrm{p}}.$$

另一方面，把上面关于 $\boldsymbol{c}$ 的表达式用到最优解 $\boldsymbol{x}^{\star}$ 上，得到

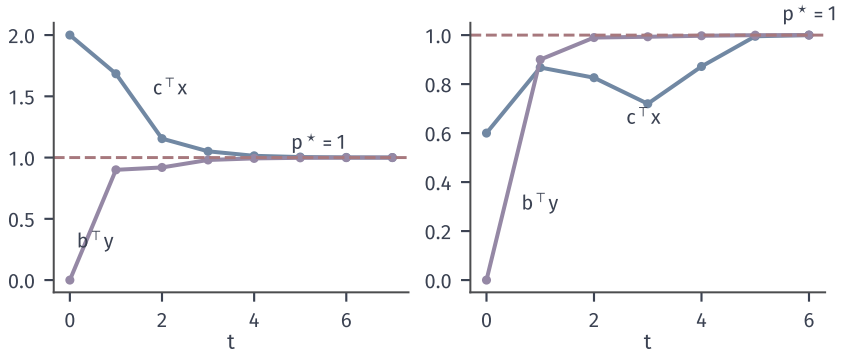
$$p^{\star} = \boldsymbol{c}^{\top}\boldsymbol{x}^{\star} = \boldsymbol{b}^{\top}\boldsymbol{y} + \boldsymbol{s}^{\top}\boldsymbol{x}^{\star} - \boldsymbol{r}_{\mathrm{d}}^{\top}\boldsymbol{x}^{\star}.$$

由 $\boldsymbol{s}^{\top}\boldsymbol{x}^{\star} \geq 0$ 和式 (4.36)，得到上界。合起来就是

$$(\boldsymbol{y}^{\star})^{\top}\boldsymbol{r}_{\mathrm{p}} \leq \boldsymbol{c}^{\top}\boldsymbol{x} - p^{\star} \leq \boldsymbol{x}^{\top}\boldsymbol{s} + \boldsymbol{r}_{\mathrm{p}}^{\top}\boldsymbol{y} + \boldsymbol{r}_{\mathrm{d}}^{\top}(\boldsymbol{x}^{\star} - \boldsymbol{x}). \tag{4.37}$$

这个结果的含义是，等式残差被最优解的大小放大。左端里 $\boldsymbol{y}^{\star}$ 相当于影子价格：原始残差 $\boldsymbol{r}_{\mathrm{p}}$ 相当于多用了或少用了资源，目标可以因此偏离 $(\boldsymbol{y}^{\star})^{\top}\boldsymbol{r}_{\mathrm{p}}$。所以 $\boldsymbol{x}^{\top}\boldsymbol{s}$ 小并不代表目标差小，还要等式残差足够小。

图 4.14展示了这种差别。图 (a) 的起点严格可行，蓝线 $\boldsymbol{c}^{\top}\boldsymbol{x}$ 从上方、紫线 $\boldsymbol{b}^{\top}\boldsymbol{y}$ 从下方夹住 $p^{\star} = 1$，这就是定理 4.7。图 (b) 的起点是 $\boldsymbol{x} = 0.1\mathbf{1}$、$\boldsymbol{s} = \mathbf{1}$、$y = 0$，等式不成立，蓝线一度在红线下方，说明此时目标值比最优值还小，并不是好事，这和第 1章资源分配中那个超出资源的点是同一种现象。



(a) 严格可行起点　(b) 不可行起点

图 4.14　原始目标（蓝）与对偶目标（紫）的夹逼，红色虚线是 $p^\star = 1$，$\sigma = 0.3$。(a) 严格可行起点，两条线从两侧夹住最优值，差距等于 $\boldsymbol{x}^\top \boldsymbol{s}$。(b) 不可行起点 $\boldsymbol{x} = 0.1\mathbf{1}$、$\boldsymbol{s} = \mathbf{1}$、$y = 0$，前几轮原始目标低于最优值，原始目标甚至低于对偶目标。

用图 (b) 的第一轮结果核对。那一点的数据是

$$\boldsymbol{x} \approx (0.1744, 0.1521, 0.1298)^\top, \qquad y = 0.9, \qquad \boldsymbol{s} \approx (0.1, 0.3231, 0.5463)^\top,$$

等式残差和目标值是

$$r_{\mathrm{p}} \approx -0.5438, \qquad \boldsymbol{r}_{\mathrm{d}} \approx (0, -0.7769, -1.5537)^\top, \qquad \boldsymbol{c}^\top \boldsymbol{x} \approx 0.8678.$$

这时 $\boldsymbol{x}^\top \boldsymbol{s} \approx 0.1375$ 是正的，但 $\boldsymbol{c}^\top \boldsymbol{x} - \boldsymbol{b}^\top \boldsymbol{y} \approx -0.0322$ 是负的，与式 (4.36)的右端一致。

目标误差 $\boldsymbol{c}^\top \boldsymbol{x} - p^\star \approx -0.1322$ 落在式 (4.37)的两端之间：左端 $y^\star r_{\mathrm{p}} \approx -0.5438$，右端约为 -0.0322。

近似解与精确解　停止时得到的点满足式 (4.34)，这是在给定容差和浮点运算下的结论。它和精确最优解是两回事，具体差别至少有三处。

第一，它通常不可行：$\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 只成立到舍入误差，$\boldsymbol{x} > \mathbf{0}$ 只在严格的算术上成立。第二，它不是顶点：贯穿例第 7 轮的 x_2, x_3 是 2×10^{-4} 和 1×10^{-4}，并不是零，把它们置零之后等式又不成立了。第三，浮点解的最后几位受舍入和 $\boldsymbol{M}$ 的条件数影响，容差设得过小并不会让结果更准，反而可能使线性系统求解失败。

所以报告结果时应当把三项残差一起报告，说明容差和尺度。“求解成功”指的只是这三项达标，至于是否足够精确，要看用途。

基恢复 有些用途需要一个基：要接着用单纯形法作参数分析（第 3章），要作整数规划的分支，或者需要一个顶点解。内点法不直接给出基，要从近似解转换，这一过程称为**基恢复**（crossover）。

做法分两阶段。先由 $\hat{\boldsymbol{x}}$ 和 $\hat{\boldsymbol{s}}$ 猜测哪些变量为正，例如比较 $\hat{x}_i$ 与 $\hat{s}_i$ 的大小，把判为零的 x_i 置零，并在其余列上修正使等式成立。然后，判为正的变量可能多于 m 个，这时沿 $\boldsymbol{A}$ 的零空间方向移动，保持目标不变并把多余的变量逐个推到零，直到剩下的列线性无关；对偶一侧作类似的推动。最后得到一个基，用单纯形法的计算重新求出解并检查符号。

以第 4.1节目标 $\boldsymbol{c} = (0,0,1)$ 的例子说明。设内点法输出近似解 $\hat{\boldsymbol{x}} = (0.4995, 0.4995, 0.001)^{\mathsf{T}}$，$\hat{\boldsymbol{s}}$ 的前两个分量很小，第三个分量接近 1。比较大小后判定 $x_3 = 0$，并修正成 $(1/2, 1/2, 0)^{\mathsf{T}}$。

正的变量有两个，而 $m = 1$，还多一个。沿零空间方向 $\boldsymbol{d} = (1,-1,0)^{\mathsf{T}}$ 移动，目标不变，走到 $x_2 = 0$，得到顶点 $(1,0,0)^{\mathsf{T}}$，基是 $B = (1)$，如图 4.15。

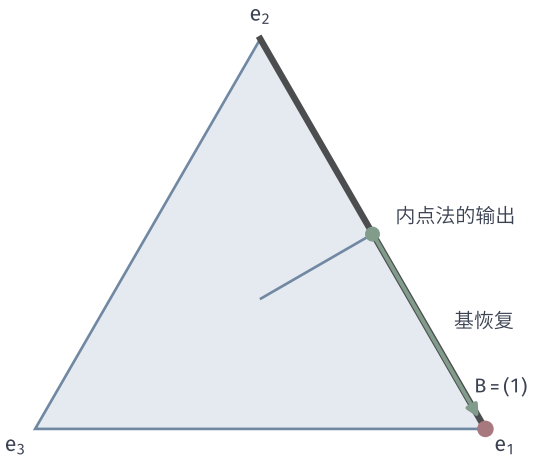


图 4.15 基恢复的一步。目标 $\boldsymbol{c} = (0,0,1)$，深灰粗线是最优边，蓝线是中心路径。内点法的输出（绿点）靠近最优边的中点，沿最优边的方向推到端点 $\boldsymbol{e}_1$（红点），得到基 $B = (1)$。推向 $\boldsymbol{e}_2$ 同样得到一个最优基，所以恢复的基不唯一。

用这个基作检验。$\boldsymbol{x}_B = 1$，对偶是 $\boldsymbol{y} = \boldsymbol{A}_B^{-\mathsf{T}} c_1 = 0$，约化成本是

$$\boldsymbol{s} = \boldsymbol{c} - \boldsymbol{A}^{\mathsf{T}}\boldsymbol{y} = (0,0,1)^{\mathsf{T}} \geq \boldsymbol{0},$$

基是最优的。如果符号检验失败，从这个基继续作若干次单纯形换基。基恢复的工作量取决于 $\hat{\boldsymbol{x}}$ 的正分量比 m 多多少，以及猜测的准确程度。已知严格互补解时恢复最优基只需多项式次运算，但实际耗时可能超过内点迭代本身。

4.1 中心路径
4.2 原始—对偶路径跟踪
4.3 初始点
4.4 求解精度
4.5 多项式复杂度
4.6 单纯形法与内点法的比较
4.7 本章小结

精确证书 基恢复之后得到的基和解还是浮点数算出的。如果数据是有理数，又需要严格证书，要再走一步。基矩阵 $\boldsymbol{A}_B$ 本身是精确的，所以可以用有理数运算重新计算

$$\boldsymbol{x}_B = \boldsymbol{A}_B^{-1}\boldsymbol{b}, \qquad \boldsymbol{y} = \boldsymbol{A}_B^{-\mathsf{T}}\boldsymbol{c}_B, \qquad \boldsymbol{s} = \boldsymbol{c} - \boldsymbol{A}^{\mathsf{T}}\boldsymbol{y}, \tag{4.38}$$

并精确地检查 $\boldsymbol{x}_B \geq \boldsymbol{0}$ 和 $\boldsymbol{s} \geq \boldsymbol{0}$。这种检查不受任何舍入影响，通过时就是严格的最优性证明，这一点和第 2章的证书完全一致。

另一种办法是先把浮点解有理化，再验算。由 Cramer 法则，基本解的分母整除 $\det \boldsymbol{A}_B$。两个分母都不超过 Q 的不同有理数至少相差 $1/Q^2$，所以浮点解的误差只要小于 $1/(2Q^2)$，分母不超过 Q 的最近有理数就只有一个，可以通过连分数求出，然后再用精确运算核对。

例如把贯穿例的约束改成 $3x_1 + x_2 + x_3 = 1$，最优解是 $x_1 = 1/3$。设内点法和基恢复给出 $\hat{x}_1 = 0.33333341$。这里 $\det \boldsymbol{A}_B = 3$，分母不超过 3 的最近有理数是 $1/3$。在基 $B = (1)$ 上按式 (4.38)作精确计算，得到

$$x_1 = \frac{1}{3}, \qquad y = \frac{1}{3}, \qquad \boldsymbol{s} = \left(0, \frac{5}{3}, \frac{8}{3}\right)^{\mathsf{T}} \geq \boldsymbol{0}.$$

这是一张可以逐项核对的最优性证书。

图 4.16把这几个阶段连起来。算法名义上“求解完成”可以停在其中任何一个阶段，每一阶段交出的东西含义不同：近似的内部点、一个基、一个浮点最优性检验通过的基、一张严格的证书。使用结果时要分清拿到的是哪一种。

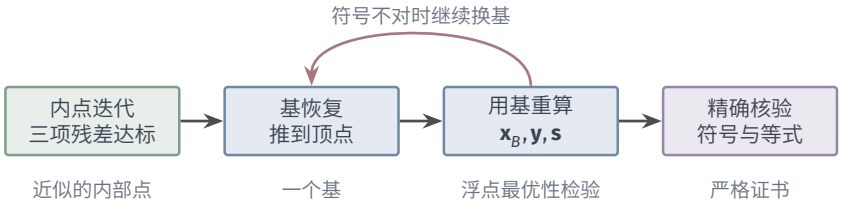


图 4.16 从内点迭代到严格证书的各个阶段。下方灰字是每个阶段交出的结果，红色箭头表示基恢复后符号检验不通过时继续换基。

4.5 多项式复杂度

单纯形法的换基次数在最坏情形下可以随维数指数增长。内点法能不能给出一个随规模温和增长的迭代次数上界？我们用最容易分析的短步路径跟踪来证明这样的界，再把它翻译成对整个算法运算量的陈述，最后指出这条界和实用规则的距离。

中心路径邻域　分析的关键是不能让迭代点离路径太远，否则 Newton 线性化不再可靠。把“靠近路径”写成一个可以检验的条件：

定义 4.8　中心路径的 $\mathcal{N}_2$ 邻域　对 $\theta \in (0,1)$，定义

$$\mathcal{N}_2(\theta) = \{(\boldsymbol{x},\boldsymbol{y},\boldsymbol{s}) \in \mathcal{F}^\circ : \|\boldsymbol{X}\boldsymbol{S}\mathbf{1} - \mu\mathbf{1}\|_2 \le \theta\mu\}, \tag{4.39}$$

其中 $\mu = \boldsymbol{x}^\top \boldsymbol{s}/n$。

条件说的是：把 n 个乘积看成一个向量，它偏离平均值的欧氏长度不超过平均值的 θ 倍。中心路径上这个偏差是零。这个集合里的每个点都满足 $x_i s_i \ge (1-\theta)\mu > 0$，所以离边界有一定的相对距离。

短步算法　短步路径跟踪用可行起点，固定取单位步长，让 μ 每轮按一个很接近 1 的比例减小：

$$\sigma = 1 - \frac{0.4}{\sqrt{n}}, \qquad \alpha = 1, \qquad \theta = 0.4. \tag{4.40}$$

这里 σ 必须和 $\sqrt{n}$ 有关，直观的理由是：μ 的相对变化如果太大，乘积向量要移动的距离就会超出邻域。

证明的核心是控制被丢掉的二阶项 $\Delta x_i \Delta s_i$。先准备一个关于向量分量乘积的引理。

引理 4.9　分量乘积的界　设 $\boldsymbol{u},\boldsymbol{v} \in \mathbb{R}^n$，$\boldsymbol{u}^\top\boldsymbol{v} \ge 0$。记 $\boldsymbol{U} = \operatorname{diag}(\boldsymbol{u})$，$\boldsymbol{V} = \operatorname{diag}(\boldsymbol{v})$，则

$$\|\boldsymbol{U}\boldsymbol{V}\mathbf{1}\|_2 \le 2^{-3/2}\|\boldsymbol{u}+\boldsymbol{v}\|_2^2. \tag{4.41}$$

证明　把下标分成 $P = \{i : u_i v_i \ge 0\}$ 和 $Q = \{i : u_i v_i < 0\}$。由 $\boldsymbol{u}^\top\boldsymbol{v} \ge 0$，

$$\sum_{i\in Q} |u_i v_i| \le \sum_{i\in P} u_i v_i.$$

对 $i \in P$，由 $u_i v_i \le (u_i+v_i)^2/4$，得到

$$\sum_{i\in P} u_i v_i \le \frac{1}{4}\sum_{i\in P}(u_i+v_i)^2 \le \frac{1}{4}\|\boldsymbol{u}+\boldsymbol{v}\|_2^2.$$

于是，用向量的 2 范数不超过 1 范数，

$$\|\boldsymbol{U}\boldsymbol{V}\mathbf{1}\|_2^2 \le \Big(\sum_{i\in P} u_i v_i\Big)^2 + \Big(\sum_{i\in Q}|u_i v_i|\Big)^2 \le 2\Big(\frac{1}{4}\|\boldsymbol{u}+\boldsymbol{v}\|_2^2\Big)^2.$$

两边开方即得。 ■

定理 4.10 短步路径跟踪的迭代次数 设 $(\boldsymbol{x}^{(0)}, \boldsymbol{y}^{(0)}, \boldsymbol{s}^{(0)}) \in \mathcal{N}_2(0.4)$，按式 (4.17)、(4.40)迭代。则所有迭代点都在 $\mathcal{N}_2(0.4)$ 中，$\mu^{(t+1)} = \sigma\mu^{(t)}$，并且当

$$T \geq 2.5\sqrt{n}\,\log\frac{n\mu^{(0)}}{\varepsilon} \tag{4.42}$$

时，$(\boldsymbol{x}^{(T)})^{\mathsf{T}}\boldsymbol{s}^{(T)} \leq \varepsilon$。

证明 记当前点在 $\mathcal{N}_2(\theta)$ 中，$\theta = 0.4$，μ 为平均互补量。证明分四步。

第一步，二阶项的大小。令 $\boldsymbol{R} = (\boldsymbol{X}\boldsymbol{S})^{1/2}$，并定义缩放后的方向

$$\boldsymbol{u} = \boldsymbol{R}\boldsymbol{X}^{-1}\Delta\boldsymbol{x}, \qquad \boldsymbol{v} = \boldsymbol{R}\boldsymbol{S}^{-1}\Delta\boldsymbol{s}.$$

当前点可行，所以 $\Delta\boldsymbol{x}^{\mathsf{T}}\Delta\boldsymbol{s} = 0$，从而 $\boldsymbol{u}^{\mathsf{T}}\boldsymbol{v} = 0$。方程组第三行给出

$$\boldsymbol{u} + \boldsymbol{v} = \boldsymbol{R}^{-1}\big(\boldsymbol{S}\Delta\boldsymbol{x} + \boldsymbol{X}\Delta\boldsymbol{s}\big) = \boldsymbol{R}^{-1}\big(\sigma\mu\mathbf{1} - \boldsymbol{X}\boldsymbol{S}\mathbf{1}\big).$$

由引理 4.9，注意到 $\boldsymbol{U}\boldsymbol{V}\mathbf{1} = \Delta\boldsymbol{X}\Delta\boldsymbol{S}\mathbf{1}$，以及 $\boldsymbol{R}^{-2}$ 的对角元不超过 $1/((1-\theta)\mu)$，得到

$$\|\Delta\boldsymbol{X}\Delta\boldsymbol{S}\mathbf{1}\|_2 \leq \frac{2^{-3/2}}{(1-\theta)\mu}\|\sigma\mu\mathbf{1} - \boldsymbol{X}\boldsymbol{S}\mathbf{1}\|_2^2.$$

第二步，计算右端。把 $\sigma\mu\mathbf{1} - \boldsymbol{X}\boldsymbol{S}\mathbf{1}$ 写成 $(\mu\mathbf{1} - \boldsymbol{X}\boldsymbol{S}\mathbf{1}) - (1-\sigma)\mu\mathbf{1}$。两部分正交，因为 $\boldsymbol{X}\boldsymbol{S}\mathbf{1} - \mu\mathbf{1}$ 的分量之和是 $n\mu - n\mu = 0$。由勾股定理和邻域条件，

$$\|\sigma\mu\mathbf{1} - \boldsymbol{X}\boldsymbol{S}\mathbf{1}\|_2^2 \leq \theta^2\mu^2 + (1-\sigma)^2 n\mu^2.$$

代入 $\theta = 0.4$ 与 $(1-\sigma)^2 n = 0.16$，结合上一步，得到

$$\|\Delta\boldsymbol{X}\Delta\boldsymbol{S}\mathbf{1}\|_2 \leq \frac{0.32}{2^{3/2}\times 0.6}\,\mu < 0.19\,\mu.$$

第三步，新点仍在邻域内。对 $\alpha \in [0,1]$，记 $\boldsymbol{x}(\alpha) = \boldsymbol{x} + \alpha\Delta\boldsymbol{x}$，$\boldsymbol{s}(\alpha)$ 同理。由第三行，

$$x_i(\alpha)s_i(\alpha) = (1-\alpha)x_i s_i + \alpha\sigma\mu + \alpha^2\Delta x_i\Delta s_i.$$

前两项之和不小于 $\min\{(1-\theta)\mu, \sigma\mu\} \ge 0.6\mu$（$n \ge 1$ 时 $\sigma \ge 0.6$），第三项的绝对值不超过 0.19μ，所以 $x_i(\alpha)s_i(\alpha) > 0$。乘积从正数出发一直为正，$x_i(\alpha)$ 和 $s_i(\alpha)$ 就不能变号，因此 $\boldsymbol{x}^+, \boldsymbol{s}^+ > \mathbf{0}$。

$\Delta\boldsymbol{x}^{\mathsf{T}}\Delta\boldsymbol{s} = 0$ 说明 $\mu^+ = \sigma\mu$。$\alpha = 1$ 时，上面的展开给出 $x_i^+ s_i^+ - \sigma\mu = \Delta x_i \Delta s_i$，于是

$$\|\boldsymbol{X}^+\boldsymbol{S}^+\mathbf{1} - \mu^+\mathbf{1}\|_2 < 0.19\,\mu \le 0.4\,\sigma\mu = \theta\mu^+,$$

最后一步用到 $0.4\sigma \ge 0.24$。等式约束由线性性保持，所以新点在 $\mathcal{N}_2(0.4)$ 中。

第四步，计数。由上面的结论，$n\mu^{(T)} = n\sigma^T\mu^{(0)}$。利用 $\log(1-\beta) \le -\beta$，只要式 (4.42)成立，就有

$$n\mu^{(T)} \le n\mu^{(0)} \exp\!\Big(-\frac{0.4\,T}{\sqrt{n}}\Big) \le \varepsilon. \qquad \blacksquare$$

这个定理的结构可以这样概括：θ 保证 Newton 步的二阶项足够小，σ 的取法让一步能被邻域容纳，两者的相容性来自 $\sqrt{n}$ 这个因子。由于 $(1-\sigma)^2 n$ 要固定，每步减少的比例只能是 $1/\sqrt{n}$ 量级，这就是迭代次数含 $\sqrt{n}$ 的原因。

以贯穿例验证。从中心点 $\boldsymbol{x}^{(0)} = (6/11, 3/11, 2/11)^{\mathsf{T}}$、$y^{(0)} = 0$ 出发，$n = 3$，$\sigma = 1 - 0.4/\sqrt{3} \approx 0.7691$，起点和前两轮的 μ 是 0.5455、0.4195、0.3226，每轮都乘以 σ。全程相对偏差的最大值约为 0.045，远小于 0.4。

取 $\varepsilon = 10^{-3}$，式 (4.42)给出的上界是

$$2.5\sqrt{3}\,\log\frac{18/11}{10^{-3}} \approx 32.04,$$

实际用了 29 轮。短步规则的实际轮数几乎就是理论值，因为 σ 是预先固定的。作为对照，第 4.2节同一个问题用预测—校正把互补量降到 10^{-3} 以下只需 4 轮。

从迭代次数到运算量　式 (4.42)只计迭代次数。要说“线性规划可以在多项式时间内求解”，还要计入每一轮的代价和数字的长度。整个结论由下面三部分拼成。

第一是每轮的算术运算量：解一个 $m \times m$ 的稠密方程组，需要 $O(n^3)$ 次算术运算（$m \le n$）。第二是迭代次数中的 $\log(n\mu^{(0)}/\varepsilon)$，要说清起点和精度是多少。

第三部分是输入的位长。设数据全部是整数，写出整个问题需要 L 个二进制位，这里 L 至少是 m, n 和各系数位数的总和。可以证明两件事：存在

满足定理条件的起点，其 $\mu^{(0)}$ 不超过 $2^{O(L)}$，这类起点由第 4.3节的嵌入构造给出；只要把间隙降到 $2^{-O(L)}$ 以下，由于有理顶点的分母有界，就可以把近似解精确地修整成最优基。

把这三部分合起来，得到迭代次数 $O(\sqrt{n}L)$，算术运算总量 $O(n^{3.5}L)$，运算中只需保留 $O(L)$ 位的精度，总的二进制运算量是 L 和 n 的多项式。严格的推导要逐项跟踪精度和起点，篇幅较长，读者可查阅专著[3]。

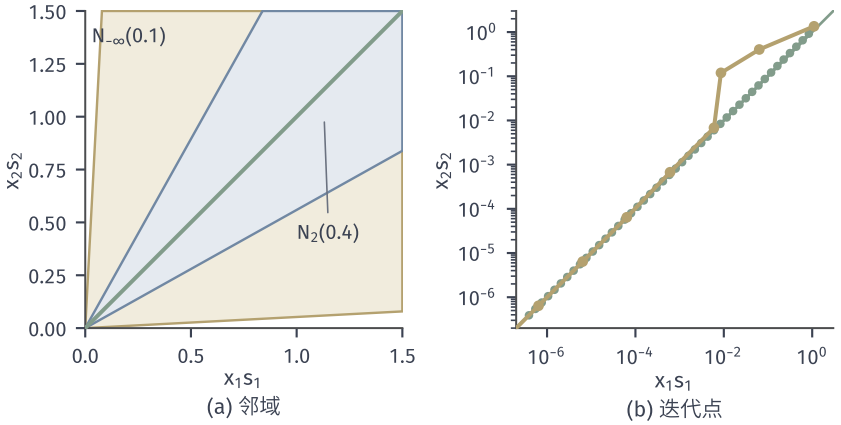
这里“多项式”的含义要说准。上面的界依赖 L，也就是系数的位数，所以这是位模型下的多项式时间，又称弱多项式。是否存在迭代次数只依赖 m, n、不依赖系数位长的线性规划算法，至今仍是公开问题。内点法的 $\log(1/\varepsilon)$ 项在这里起作用：想要精确解，就需要把精度推到由 L 决定的程度。

[3] D. Bertsimas, J. N. Tsitsiklis, *Introduction to Linear Optimization*, Athena Scientific, 1997

理论规则与实用规则 短步规则的上界最好，实际却很慢：它每轮只减小约 $0.4/\sqrt{n}$，从不利用可以走更远的情况。放宽邻域能让步子变大。定义单侧邻域

$$\mathcal{N}_{-\infty}(\gamma)=\{(\boldsymbol{x},\boldsymbol{y},\boldsymbol{s})\in\mathcal{F}^{\circ}:x_i s_i\geq\gamma\mu,\ i=1,\dots,n\},\quad \gamma\in(0,1). \tag{4.43}$$

γ 很小时，几乎只要求每个乘积不要低于平均值太多。图 4.17(a) 是 $n=2$ 时两种邻域在乘积平面上的形状：$\mathcal{N}_2$ 是窄条，$\mathcal{N}_{-\infty}$ 几乎占满整个象限。



(a) 邻域　(b) 迭代点

图 4.17　$n=2$ 时中心路径的邻域，横纵轴是两个乘积 x_1s_1, x_2s_2，绿色对角线是中心路径。(a) 蓝色是 $\mathcal{N}_2(0.4)$，黄色是 $\mathcal{N}_{-\infty}(0.1)$。(b) 问题 $\min x_1+2x_2$、$x_1+x_2=1$ 上的迭代点，对数坐标。绿点是短步规则，黄点是 $\sigma=0.1$ 的长步规则，长步规则离路径更远，点数少得多。

在 $\mathcal{N}_{-\infty}(\gamma)$ 上，每轮取较小的 σ，再沿方向走到将要离开邻域为止，称为长步路径跟踪。它的理论上界是 $O(n\log(1/\varepsilon))$，比短步的 $O(\sqrt{n}\log(1/\varepsilon))$ 差，实际表现却远好于短步。

第 4.2节的预测—校正规则则按式 (4.28)自适应地选 σ，加上二阶校正。按通常的写法，它没有多项式的迭代次数保证，但它是大规模求解器的常用方案。

图 4.18是随机线性规划上的迭代次数。每个问题都从同一个中心点出发，要求 $\mu \le 10^{-6}$。短步规则的轮数紧贴理论值，随 $\sqrt{n}$ 增长，$n = 1000$ 时超过一千轮。长步规则和预测—校正增长得慢得多，$n = 1000$ 时只需 23 轮和 12 轮。

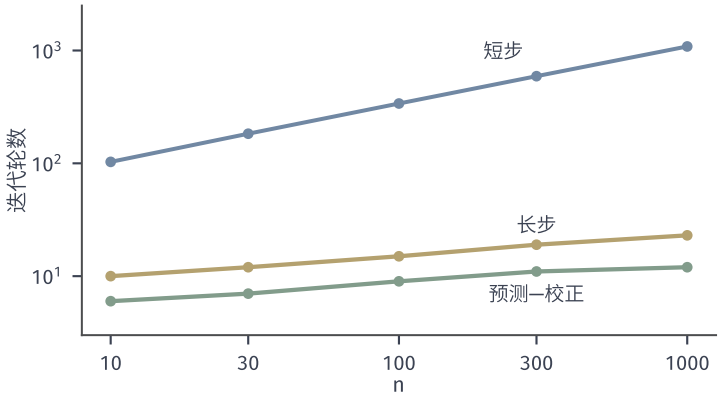


图 4.18　随机稠密线性规划上三种规则的迭代轮数，$m = n/2$，对数坐标，起点 $\boldsymbol{x} = \boldsymbol{s} = \mathbf{1}$ 是中心点，停止条件 $\mu \le 10^{-6}$。蓝线是短步规则，黄线是长步规则 ($\sigma = 0.1$、$\gamma = 10^{-3}$)，绿线是预测—校正。每个 n 只运行一个固定种子的实例，用来展示量级而不是平均表现。

表 4.2把三者放在一起。理论界最好的规则不是实践中最快的规则，这个差距是内点法的一个基本事实。

规则	邻域	迭代上界	实践表现
短步	$\mathcal{N}_2(0.4)$	$O(\sqrt{n}\log(1/\varepsilon))$	接近理论值，很慢
长步	$\mathcal{N}_{-\infty}(\gamma)$	$O(n\log(1/\varepsilon))$	轮数少
预测—校正	无固定邻域	无一般保证	通常最少

表 4.2　三种路径跟踪规则的比较。上界针对可行起点；预测—校正指式 (4.28)的常用写法，加上保护措施的变体可以恢复多项式界。

历史上的位置　线性规划的多项式可解性最早不是由内点法确立的。1979 年，Khachiyan 用椭球法证明了线性规划可以在多项式时间内求解，这个方法每步用一个椭球包住可能的解集，并不断缩小椭球。它在理论上解决了问题，实际计算却很慢。

1984 年 Karmarkar 提出的算法同样具有多项式复杂度，并且在实践中有竞争力，随后的工作发展出本章的原始—对偶路径跟踪。这段历史可以

帮助分清两件事：多项式界回答“最坏情形下随规模怎样增长”，实际快慢还取决于常数、结构和实现。

4.1 中心路径
4.2 原始—对偶路径跟踪
4.3 初始点
4.4 求解精度
4.5 多项式复杂度
4.6 单纯形法与内点法的比较
4.7 本章小结

4.6 单纯形法与内点法的比较

现在两种算法都有了。于是要问：面对一个具体的线性规划，两者各需要做什么、各能交出什么？我们先在同一个工厂问题上把它们并排算一遍，再按稀疏性、内存、退化和再求解几个方面对比。

同一个问题上的两种计算 工厂问题的标准型是第 3章的数据，$m=3$，$n=5$，最优解是 $(4,2,0,0,1)^{\top}$，最优利润 26，对偶最优解 $\boldsymbol{y}^{\star}=(-2,-1,0)^{\top}$。单纯形法从基 $(3,4,5)$ 出发，经过 $(0,3)$、$(2,3)$，3 次换基到达最优顶点，每次换基求解一个 3×3 的基矩阵方程组。

内点法取严格可行起点

$$\boldsymbol{x}^{(0)}=(1,1,5,7,2)^{\top},\qquad \boldsymbol{y}^{(0)}=(-3,-3,-3)^{\top},\qquad \boldsymbol{s}^{(0)}=(5,7,3,3,3)^{\top},$$

这里 $\boldsymbol{s}^{(0)}=\boldsymbol{c}-\boldsymbol{A}^{\top}\boldsymbol{y}^{(0)}$，$\mu^{(0)}=10.8$。第一轮的正规矩阵是

$$\boldsymbol{M}=\boldsymbol{A}\boldsymbol{D}\boldsymbol{A}^{\top}\approx\begin{bmatrix}2.4381 & 0.6857 & 0.2857\\ 0.6857 & 3.2762 & 0.1429\\ 0.2857 & 0.1429 & 0.8095\end{bmatrix}.$$

两种算法都在解 3×3 的对称或非对称方程组，表面上规模一样，含义却不同。基矩阵只用 $\boldsymbol{A}$ 的 3 列，换基时只变一列；$\boldsymbol{M}$ 用到全部 5 列，每轮的数值都变，但元素的稀疏结构不变。

用预测—校正（$\eta=0.99$），6 轮后互补量从 54 降到约 1.2×10^{-7}，点在 4 位小数上就是 $(4,2,0,0,1)^{\top}$。

图 4.19把这两个过程画在一起。单纯形法的每一步都站在顶点上，利润单调上升，3 步后得到精确解。内点法的头几轮就穿过内部接近最优点，第 3 轮已到 25.95，但此后每轮只是把小数位往后推，点始终不是顶点。

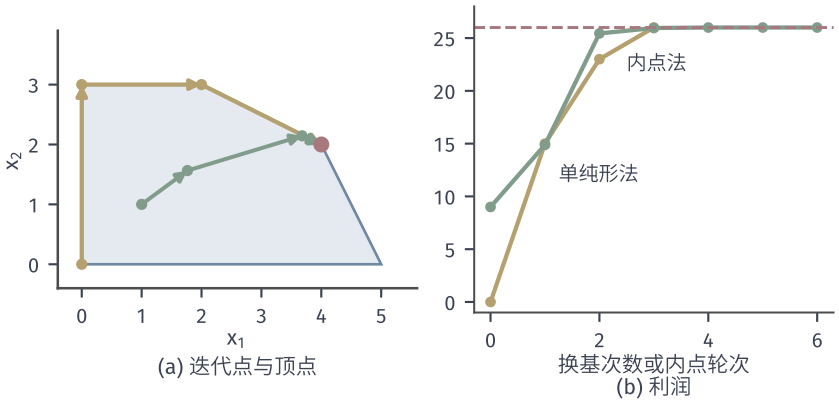


图 4.19 工厂问题上的两种算法。(a) 可行域上，黄色是单纯形法的顶点序列，绿色是内点法的前几个迭代点，红点是最优顶点 $(4, 2)$。(b) 利润随迭代的变化，黄线是单纯形法的换基次数，绿线是内点法的轮次，红色虚线是最优值 26。单纯形法的横轴单位是一次换基，内点法的单位是一次分解 $\boldsymbol{M}$，两者的代价不同，不能只比轮次。

稀疏存储与分解填充 大规模线性规划的矩阵 $\boldsymbol{A}$ 几乎都是稀疏的，这时代价取决于分解时产生多少新的非零元（填充）。两种算法的填充模式不同。

单纯形法分解基矩阵，用 LU 分解并在换基时更新，只涉及 m 列。内点法分解 $\boldsymbol{ADA}^{\mathsf{T}}$，它的第 (i, k) 个元素非零，当且仅当存在一列在第 i 行和第 k 行都非零。于是只要 $\boldsymbol{A}$ 有一列稠密，$\boldsymbol{M}$ 就整个稠密。

图 4.20是一个例子：$\boldsymbol{A}$ 是 40×80 的稀疏矩阵，每列只有两个非零元，再加上一个稠密列。整个 $\boldsymbol{A}$ 只有 198 个非零元，$\boldsymbol{M}$ 却有全部 1600 个；去掉那一列后，$\boldsymbol{M}$ 只有 196 个非零元。实现中会把稠密列单独分离出来，用矩阵求逆引理处理，但这需要额外的数值稳定措施。

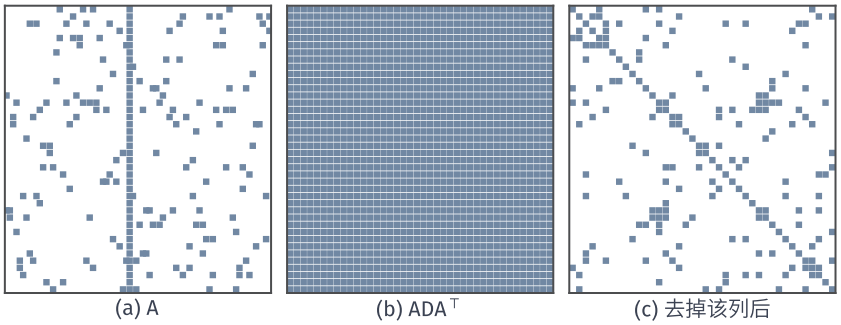


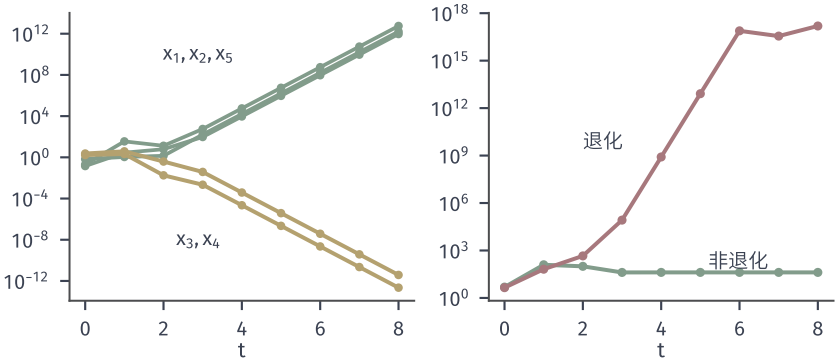
图 4.20 一个稠密列的影响，蓝色方块表示非零元。(a)40×80 的稀疏矩阵 $\boldsymbol{A}$，其中一列稠密。(b) 正规矩阵 $\boldsymbol{ADA}^{\mathsf{T}}$ 完全稠密。(c) 去掉该列后的 $\boldsymbol{ADA}^{\mathsf{T}}$ 仍然稀疏。

内存 内点法每轮要存 $\boldsymbol{M}$ 的 Cholesky 因子，内存由填充决定，并且在整个求解期间都要占用这么多。单纯形法只存基的 LU 因子，通常比前者小，

但可能需要很多次换基。所以问题规模增大时，内点法更容易受内存限制，单纯形法更容易受迭代次数限制，具体哪个先成为瓶颈取决于矩阵结构。

退化与数值性质 第 3章说明，退化时单纯形法可能原地换基，需要反循环规则。内点法从不访问顶点，路径本身不受退化的基影响，第 t 轮的 $\boldsymbol{D}$ 只和当前点有关，因此没有“卡在同一顶点”的现象。

内点法的麻烦在别处。$\boldsymbol{D}$ 的对角元是 x_i/s_i，随迭代趋于两个极端：最优解中为正的变量对应的元素趋于 $+\infty$，为零的变量对应的元素趋于 0。图 4.21(a) 显示，工厂问题最后几轮对角元的比值已超过 10^{20}。



(a) 缩放矩阵的对角元　　(b) 正规方程矩阵的条件数

图 4.21　缩放矩阵与条件数的变化，预测—校正，$\eta = 0.99$。(a) 工厂问题中 $D_{ii} = x_i/s_i$ 随轮次的变化，绿线对应最优解中为正的 x_1, x_2, x_5，黄线对应为零的 x_3, x_4。(b)$\boldsymbol{M} = \boldsymbol{A}\boldsymbol{D}\boldsymbol{A}^{\top}$ 的 2 范数条件数：绿线是非退化的工厂问题，红线是再加一条约束 $x_1 + x_2 \le 6$ 使最优顶点退化的情形。

这种悬殊看起来很危险，影响却取决于问题的结构。图 4.21(b) 的绿线说明，非退化时 $\boldsymbol{M}$ 由三个正的基变量主导，它们的 D_{ii} 同步增大，条件数稳定在约 41。红线是最优顶点退化的情形，正变量少于 m 个，$\boldsymbol{M}$ 趋于奇异，条件数涨到 10^{16} 以上。

大的条件数并不直接意味着算出的方向没用：误差往往落在对后续更新影响不大的子空间里，这是内点法在实践中比条件数预示的更稳健的原因，但这需要专门的误差分析，读者可查阅专著[4]。求解器还要辅以正则化和迭代精化。最终都应当检查残差，不能只凭条件数判断。

[4] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

基与再求解 单纯形法返回一个基，这使很多后续工作很方便：约束或目标有微小改变时，从原来的基接着做，往往几次换基就够（第 3章的对偶单纯形法）；固定基的参数分析可以直接读出结论成立的范围。

内点法也返回对偶信息，这些 $\boldsymbol{y}$ 和 $\boldsymbol{s}$ 的值可以当作影子价格用，但结果是最优面中央的一个点，解不唯一时它和某个基给出的对偶解并不相同。需要基时要做上一节的基恢复。

4.1 中心路径
4.2 原始—对偶路径跟踪
4.3 初始点
4.4 求解精度
4.5 多项式复杂度
4.6 单纯形法与内点法的比较
4.7 本章小结

内点法的热启动也比较困难。上一次的解贴近边界，某些 x_i 或 s_i 接近零，从这里出发的步长通常很短，反而不如重新开始。因此在分支限界这类需要大量相关求解的场景中，单纯形法更占优势，这也是两种方法长期并存的原因之一。

速度取决于问题和实现 两种算法都不总是更快。一般而言，内点法在规模很大且 $\boldsymbol{M}$ 稀疏时往往轮数少、速度快，单纯形法在 $\boldsymbol{M}$ 稠密或需要反复热启动时更有优势。这只是经验性的倾向，具体结果要看矩阵结构、预处理和实现水平，求解器通常提供两者甚至并行运行。

表 4.3总结了本节的对比。

4.7 本章小结

本章开头问：能不能不贴着边走，从可行域的内部穿过去？答案是把互补松弛 $x_i s_i = 0$ 放宽成 $x_i s_i = \mu$。原始和对偶都有严格可行点时，这组方程对每个 $\mu > 0$ 有唯一解，解连成中心路径，沿路径的对偶间隙恰好是 $n\mu$。路径的极限是一对严格互补的最优解，落在最优面的解析中心，解不唯一时并不是顶点。

沿路径前进靠 Newton 法。线性化 $x_i s_i = \sigma\mu$ 得到一个由原始残差、对偶残差和互补残差驱动的线性方程组，消元后只需解 $m \times m$ 的对称正定方程 $\boldsymbol{A}\boldsymbol{D}\boldsymbol{A}^{\top}\Delta\boldsymbol{y} = \boldsymbol{h}$。到边界的比例规则保持 $\boldsymbol{x}, \boldsymbol{s} > \boldsymbol{0}$，$\sigma$ 在减小互补量和靠近中心之间折中，预测—校正用一次试算选定 σ 并补偿二阶项，两次求解共用一次分解。

这些步骤合起来是一个完整的求解过程。起点可以严格可行，也可以只要求正性，让等式残差和互补量一起下降；需要判别不可行或无界时，用预处理和齐次自对偶嵌入。停止时要同时看三项残差，只有在原始、对偶都可行时，$\boldsymbol{x}^{\top}\boldsymbol{s}$ 才是目标误差的上界，否则还要计入等式残差被最优解放大的部分。

方面	单纯形法	内点法
每步的工作	解基矩阵方程，换一列	分解 $\boldsymbol{A}\boldsymbol{D}\boldsymbol{A}^{\top}$，全部列参与
迭代次数	随结构变化，最坏情形指数	通常很少，短步规则有 $O(\sqrt{n}\log(1/\varepsilon))$ 的界
稀疏结构	基的 LU 因子，变化较小	稠密列会使 $\boldsymbol{M}$ 稠密，需特殊处理
内存	通常较小	由 Cholesky 填充决定，通常较大
退化	可能原地换基，需反循环规则	不停滞，但 $\boldsymbol{M}$ 可能病态
交出的结果	基、顶点解、对偶解	内部的近似点和对偶量，需要基时另作恢复
再求解	从旧基热启动较容易	从旧解热启动较困难

表 4.3 单纯形法与内点法的对比。各项是对典型情形的概括，速度结论取决于问题结构和实现。无论用哪种方法，浮点实现都要检验可行性和最优性。

交付的结果有几个层次，它们的含义不同：浮点容差下的近似解，基恢复之后的基，用精确算术核对过的证书。理论方面，短步路径跟踪的迭代次数不超过 $O(\sqrt{n}\log(n\mu^{(0)}/\varepsilon))$，配合起点构造和位长分析得到线性规划的多项式算法；椭球法更早建立了这一可解性。理论规则和实用的预测—校正之间有明显差距，不能把后者的经验速度当作定理。

选择算法时，单纯形法便于热启动、返回基，适合反复求解和灵敏度分析；内点法迭代次数少，适合大规模稀疏问题，但对 $\boldsymbol{A}\boldsymbol{D}\boldsymbol{A}^{\top}$ 的填充敏感，需要基时要另作恢复。两者都需要在最后检验可行性和最优性。

路径跟踪的思路并不限于线性规划。当约束是一般的光滑函数或锥时，障碍和扰动互补仍然可用，但方程不再是双线性的，Newton 系统含有 Hessian 和 Jacobian 的变化，严格内点、初值和停止证书都有新的条件，这些由第 24章展开。

第二部分

光滑优化

Smooth Optimization

阅读指引

当目标是光滑函数时，梯度和 Hessian 告诉我们当前点附近函数怎样变化。把这些局部信息变成一步好的移动，是本部分的中心问题：走哪个方向，走多远，局部模型能相信多大范围，走到梯度很小的地方是否就算完成。

第 5章准备共同的工具：光滑性给出的二次上界、步长的接受条件和比较算法的成本口径。随后三章按所用的曲率信息划分。第 6章只用梯度和历史迭代，第 7章直接使用 Hessian，第 8章用相邻梯度之差积累曲率近似。

第 9章换一个角度组织更新：不是先定方向再定步长，而是先划定局部模型可信的范围，再在范围内求步，并用实际下降检验模型。第 10章处理非凸目标特有的困难，梯度为零的点可能是鞍点，需要利用负曲率离开，并说清算法最终能保证到什么程度。

阅读时请留意每个结论对应的目标类别。同一种算法在强凸、凸和一般非凸目标上给出的保证形式不同，评价的量也不同。

5.1 光滑性
5.2 步长的选择
5.3 求解误差与计算成本
5.4 本章小结

第 5 章

光滑优化基础

在浓雾里下山，眼前只看得清脚下一小块地面。我们能量出这块地面朝哪边倾斜、倾斜多少，却看不见十步之外的地形。于是每一步都要回答两个问题：朝哪里走，走多远。第 1章的梯度回答了第一个问题的一部分，只要方向与负梯度夹角小于直角，迈出足够小的一步，高度就会下降。

“足够小”到底是多小？步子太大，可能跨过谷底，落在对面更高的山坡上；步子太小，走到天黑也走不了多远。而且实际计算要付出代价，每量一次坡度、每试探一次落脚点的高度都要花时间。两种下山办法谁更好，也不能只数迈了多少步。

本章为后面的光滑优化方法准备共同的依据。第 5.1节规定梯度变化的速度上限，由此得到一阶预测的误差界，回答一次有限的移动最多偏离预测多少。第 5.2节固定一个下降方向，比较预先定好的步长、用函数值检验的回溯和同时检验方向导数的条件，说明什么样的候选步可以接受。第 5.3节规定怎样比较不同方法：看哪种误差、返回哪个点、把哪些计算算进去。

下一章起，各方法的差别主要在更新方向来自什么信息。至于这个方向走多远、走完怎样评价，都回到本章的规则。

5.1 光滑性

由第 1章的方向导数，当位移 $\boldsymbol{p}$ 趋于零时，$f(\boldsymbol{x}+\boldsymbol{p})$ 与线性预测 $f(\boldsymbol{x})+\langle \nabla f(\boldsymbol{x}), \boldsymbol{p}\rangle$ 的差比 $\|\boldsymbol{p}\|_2$ 更快地趋于零。算法迈出的却是有限的一步。接下来要弄清：一次有限的移动之后，目标最多偏离线性预测多少？

贯穿本章的例子　本章反复使用下面的二元二次目标：

$$f(\boldsymbol{x}) = \frac{1}{2}\left(x_1^2 + 9x_2^2\right), \qquad \boldsymbol{x}^{(0)} = (9, 1). \tag{5.1}$$

它的 Hessian 是 $\boldsymbol{H} = \operatorname{diag}(1, 9)$，最优解是原点，$f^\star = 0$。等高线是沿 x_1 方向拉长的椭圆，碗底像一条山谷。

在初始点算出目标值和梯度：

$$f(\boldsymbol{x}^{(0)}) = 45, \qquad \nabla f(\boldsymbol{x}^{(0)}) = (9, 9).$$

这个例子所有的量都能手算，而两个方向的曲率相差 9 倍，足以暴露步长选择的主要现象。

梯度变化得多快　线性预测把脚下的坡度当成一路不变。预测错多少，取决于走动时坡度变了多少。在例 (5.1)中，两点的梯度之差是

$$\nabla f(\boldsymbol{u}) - \nabla f(\boldsymbol{v}) = \boldsymbol{H}(\boldsymbol{u} - \boldsymbol{v}).$$

沿 x_1 方向移动单位长度，梯度改变 1；沿 x_2 方向移动单位长度，梯度改变 9。无论朝哪个方向走，单位位移引起的梯度变化都不超过 9。

这个数就是坡度变化的限速。有了限速，站在一点上虽然看不见远处，却可以断定走出距离 r 之后坡度至多变化多少。对一般目标，我们要求这样的限速在关心的区域内统一存在。

定义 5.1　梯度 Lipschitz 条件　设 $f : \mathbb{R}^n \to \mathbb{R}$ 可微，$\boldsymbol{U} \subseteq \mathbb{R}^n$，$L \geq 0$。若对所有 $\boldsymbol{u}, \boldsymbol{v} \in \boldsymbol{U}$，

$$\|\nabla f(\boldsymbol{u}) - \nabla f(\boldsymbol{v})\|_2 \leq L\|\boldsymbol{u} - \boldsymbol{v}\|_2, \tag{5.2}$$

就说 ∇f 在 $\boldsymbol{U}$ 上满足**梯度 Lipschitz 条件**（gradient Lipschitz condition），也说 f 在 $\boldsymbol{U}$ 上 L 光滑（L-smooth）。满足条件的 L 称为**光滑常数**（smoothness constant）。$\boldsymbol{U} = \mathbb{R}^n$ 时简称 f 是 L 光滑的。

这个定义把第 1章只对二阶可微函数使用的 L 推广了：这里不要求 Hessian 存在。图 5.1用一元函数的导数曲线说明条件的含义。以曲线上一点为顶点、作斜率为 $\pm L$ 的两条直线，得到一个双锥形。条件 (5.2)等于说，无论把顶点放在曲线的哪一点，整条曲线都留在锥内。

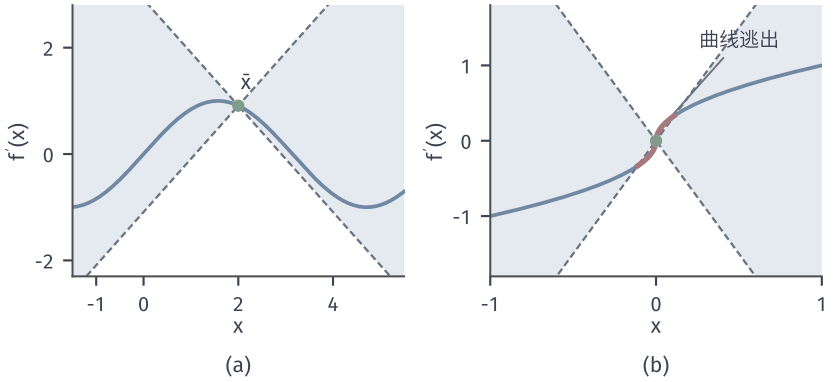


图 5.1 梯度 Lipschitz 条件的几何含义。蓝线是导数曲线，浅蓝区域是从绿点出发、斜率为 $\pm L$ 的双锥。(a)$f'(x)=\sin x$，取 $L=1$，顶点放在 $\bar{x}=2$，曲线留在锥内；顶点放在其他点时同样如此。(b)$f'(x)=\operatorname{sign}(x)|x|^{1/2}$，取 $L=3$，顶点放在 0，红色部分 $|x|<1/9$ 逃出了锥；L 再大，逃出的部分只是变短，永远存在。

三个相近的条件 “可微”“梯度连续”“梯度 Lipschitz”是逐步加强的三个要求，图 5.1(b) 的函数正好落在中间。取 $f(x)=\frac{2}{3}|x|^{3/2}$，它处处可微，导数是

$$f'(x)=\operatorname{sign}(x)|x|^{1/2},$$

这个导数也连续。但以 0 为参照点，

$$\frac{|f'(x)-f'(0)|}{|x|}=|x|^{-1/2},$$

$x\to 0$ 时趋于无穷，所以包含原点的任何区间上都没有光滑常数。

高阶可微也不能保证全局的常数。$f(x)=x^4$ 无穷次可微，而

$$\frac{|f'(u)-f'(0)|}{|u|}=4u^2,$$

u 变大时无界。限制在 $[-R,R]$ 上时，$f''(x)=12x^2\le 12R^2$，常数 $12R^2$ 随区域变大。所以说一个目标“光滑”时，要同时交代常数和它成立的区域。

下降引理 有了坡度的限速，就能控制线性预测的误差。思路是把有限的位移分成无穷多小段累加：每一小段上的真实变化由该处的坡度决定，它与起点坡度之差不超过限速乘以已走的距离。

引理 5.2 下降引理 设 $f:\mathbb{R}^n\to\mathbb{R}$ 可微，并在集合 $\boldsymbol{U}$ 上 L 光滑。若线段 $\{\boldsymbol{x}+s\boldsymbol{p}:s\in[0,1]\}$ 落在 $\boldsymbol{U}$ 中，则

$$\left|f(\boldsymbol{x}+\boldsymbol{p})-f(\boldsymbol{x})-\langle\nabla f(\boldsymbol{x}),\boldsymbol{p}\rangle\right|\le\frac{L}{2}\|\boldsymbol{p}\|_2^2. \tag{5.3}$$

特别地，

$$f(\boldsymbol{x}+\boldsymbol{p}) \le f(\boldsymbol{x}) + \langle \nabla f(\boldsymbol{x}), \boldsymbol{p}\rangle + \frac{L}{2}\|\boldsymbol{p}\|_2^2. \tag{5.4}$$

证明　令 $\phi(s) = f(\boldsymbol{x}+s\boldsymbol{p})$，$s\in[0,1]$。由链式法则，

$$\phi'(s) = \langle \nabla f(\boldsymbol{x}+s\boldsymbol{p}), \boldsymbol{p}\rangle.$$

线段在 $\boldsymbol{U}$ 中，∇f 沿线段 Lipschitz，所以 ϕ' 连续，微积分基本定理给出

$$f(\boldsymbol{x}+\boldsymbol{p}) - f(\boldsymbol{x}) = \int_0^1 \langle \nabla f(\boldsymbol{x}+s\boldsymbol{p}), \boldsymbol{p}\rangle \,\mathrm{d}s.$$

两边减去常数 $\langle \nabla f(\boldsymbol{x}), \boldsymbol{p}\rangle$，并把它也写成 s 从 0 到 1 的积分，得到

$$f(\boldsymbol{x}+\boldsymbol{p}) - f(\boldsymbol{x}) - \langle \nabla f(\boldsymbol{x}), \boldsymbol{p}\rangle = \int_0^1 \langle \nabla f(\boldsymbol{x}+s\boldsymbol{p}) - \nabla f(\boldsymbol{x}), \boldsymbol{p}\rangle \,\mathrm{d}s.$$

由 Cauchy–Schwarz 不等式和式 (5.2)，被积函数的绝对值满足

$$\left|\langle \nabla f(\boldsymbol{x}+s\boldsymbol{p}) - \nabla f(\boldsymbol{x}), \boldsymbol{p}\rangle\right| \le Ls\|\boldsymbol{p}\|_2^2.$$

对 s 从 0 积分到 1，右端成为 $\frac{L}{2}\|\boldsymbol{p}\|_2^2$，式 (5.3)成立。去掉绝对值取上半部分，即得式 (5.4)。 ■

上界 (5.4)称为**下降引理**（descent lemma），它是后面证明目标下降的主要工具。把右端看成 $\boldsymbol{p}$ 的函数，记作

$$m_L(\boldsymbol{p}) = f(\boldsymbol{x}) + \langle \nabla f(\boldsymbol{x}), \boldsymbol{p}\rangle + \frac{L}{2}\|\boldsymbol{p}\|_2^2. \tag{5.5}$$

这是一个在当前点与 f 相切、开口向上的二次函数，像一只倒扣过来的碗从上方盖住了 f。下半部分则是开口向下的二次函数，从下方托住 f。

图 5.2画出 $f(x) = 1-\cos x$ 的情形。这里 $f''(x) = \cos x$，取值在 $[-1,1]$ 内，$L=1$，当前点 $x^{(0)} = 2$。整条曲线都夹在两条抛物线之间。

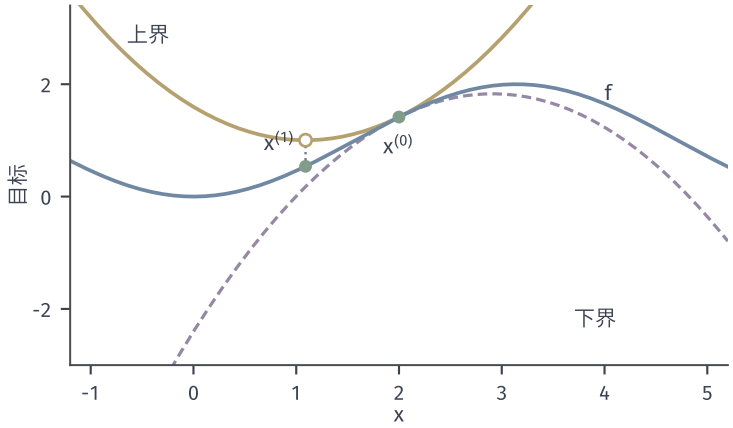


图 5.2 $f(x)=1-\cos x$ 在 $x^{(0)}=2$ 处的二次上界（黄线）与二次下界（紫色虚线），$L=1$。空心点是上界的最低点，其正下方的绿点 $x^{(1)}=2-\sin 2$ 是目标在同一位置的真实值，后者不高于前者。

上界怎样限制一步更新 上界的用途在于，它把“走到哪里”变成一个能解的问题。式 (5.5)对 $\boldsymbol{p}$ 求梯度并令其为零，最低点是

$$\boldsymbol{p}=-\frac{1}{L}\nabla f(\boldsymbol{x}).$$

代回式 (5.4)，得到一步能够保证的下降量：

$$f\Big(\boldsymbol{x}-\frac{1}{L}\nabla f(\boldsymbol{x})\Big)\le f(\boldsymbol{x})-\frac{1}{2L}\|\nabla f(\boldsymbol{x})\|_2^2. \tag{5.6}$$

这个结论的意思是：只要落点在碗的最低处，真实目标不会比碗底更高。在图 5.2的例子里，$\sin 2\approx 0.909$，当前值、碗底值和真实落点值分别是

$$f(2)\approx 1.416,\qquad m_L(-0.909)\approx 1.003,\qquad f(1.091)\approx 0.538.$$

保证的下降量是 0.413，实际下降 0.878。上界不紧，但它不需要试探就能给出保证。

回到例 (5.1)。此时 $L=9$，当前点的上界最低点是 $\boldsymbol{x}^{(1)}=(9,1)-\frac{1}{9}(9,9)=(8,0)$，碗底高度与真实值分别是

$$f(\boldsymbol{x}^{(0)})-\frac{\|\boldsymbol{g}^{(0)}\|_2^2}{2L}=45-9=36,\qquad f(\boldsymbol{x}^{(1)})=32.$$

图 5.3显示了这一步的几何。上界的等高线是圆，真实目标的等高线是椭圆。经过当前点的圆完全落在经过当前点的椭圆之内，所以圆内每一点都比当前点低。

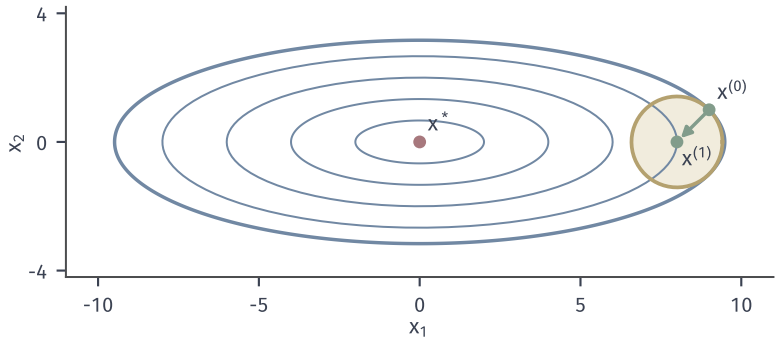


图 5.3 各向同性的上界盖住各向异性的目标。蓝线是例 (5.1)的等高线，粗线经过 $\boldsymbol{x}^{(0)}$。黄圆是上界 m_L 经过 $\boldsymbol{x}^{(0)}$ 的等高线，圆心 $\boldsymbol{x}^{(1)} = (8, 0)$ 是上界的最低点，绿色箭头是步 $-\boldsymbol{g}^{(0)}/L$。圆的半径是 $\|\boldsymbol{g}^{(0)}\|_2/L = \sqrt{2}$，比到最优解的距离小得多。

这个图也说明了上界的弱点。它只知道一个数 L，必须按最陡的方向处处提防，所以朝平坦的 x_1 方向也不敢多走。碗的类比到这里就要打折扣：真实地形是一条长谷，而这只碗是圆的，它保证安全，却不描述谷的走向。

局部模型能信多远 下降引理有一句前提：线段要落在 L 成立的区域内。这句话不能省。取 $f(x) = x^4$，当前点 $x^{(0)} = 1$，导数是 4。在 $[-1, 1]$ 上 $f'' \le 12$，取 $L = 12$，上界是

$$m(x) = 1 + 4(x - 1) + 6(x - 1)^2.$$

上界与目标之差可以因式分解，

$$f(x) - m(x) = (x - 1)^3(x + 3).$$

当 $-3 \le x \le 1$ 时它不大于零，上界盖得住；当 $x > 1$ 或 $x < -3$ 时它大于零，上界失效。

图 5.4(b) 放大了当前点附近：只要向右走一点点，f'' 就超过 12，上界立刻盖不住。向左，上界一直盖到 $x = -3$，比 L 成立的区间 $[-1, 1]$ 更远，因为靠近当前点那段曲率小于 12，积累的余量抵消了后来过大的曲率。引理只承诺线段在区域内时成立，区域外可能成立，也可能不成立。

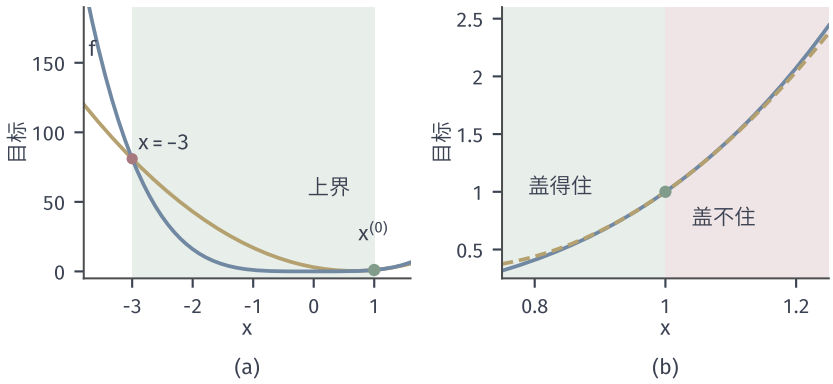


图 5.4 局部常数的有效范围。$f(x) = x^4$（蓝线），在 $x^{(0)} = 1$ 处用 $[-1, 1]$ 上的常数 $L = 12$ 作上界（黄线）。(a) 浅绿区域 $[-3, 1]$ 内上界盖住目标，$x = -3$ 是另一个交点。(b) 放大当前点附近：左侧盖得住；右侧浅红区域 $f'' > 12$，上界立刻盖不住，虚线低于蓝线。

上界与凸性无关 上界 m_L 永远是凸函数，这容易让人以为 L 光滑带有某种凸性。其实两件事互不蕴含。L 限制的是弯曲的绝对大小，凸性限制的是弯曲的方向。表 5.1用四个一元函数列出全部组合。

	凸	非凸
全局 L 光滑	$x^2/2$，$L = 1$	$1 - \cos x$，$L = 1$
无全局常数	x^4	$x^4 - x^2$

表 5.1 全局光滑性与凸性互不蕴含。第一行的函数二阶导数有界，第二行无界；第一列的函数二阶导数非负，第二列会取负值。

两者对局部模型的贡献也不同。光滑性给出二次上界，告诉我们一步最多变差多少，由此保证下降。凸性把式 (5.3)的下半部分从开口向下的抛物线提高到切平面，也就是第 1章的支撑不等式，由此才能从一点的信息推断全局。$1 - \cos x$ 在 $x^{(0)} = 3$ 附近上界依然成立，但这里的小梯度不说明接近最小点。

下水平集上的常数 实际目标常常没有全局的 L，例如 x^4。好在下降算法不必到处走：只要每步都不升高，迭代点就留在初始的下水平集里。下面的引理说明，L 只在下水平集上成立时，只要步长受限，这一步的整条线段就不会走出去，下降引理可以照用。

引理 5.3　梯度步留在下水平集内　设 $f:\mathbb{R}^n\to\mathbb{R}$ 可微，$\boldsymbol{S}=\{\boldsymbol{z}:f(\boldsymbol{z})\le a\}$，$f$ 在 $\boldsymbol{S}$ 上 L 光滑，$L>0$。设 $\boldsymbol{x}\in\boldsymbol{S}$，$\boldsymbol{g}=\nabla f(\boldsymbol{x})\neq\boldsymbol{0}$，$0<\alpha<2/L$。则线段 $\{\boldsymbol{x}-s\boldsymbol{g}:s\in[0,\alpha]\}$ 落在 $\boldsymbol{S}$ 内，并且

$$f(\boldsymbol{x}-\alpha\boldsymbol{g})\le f(\boldsymbol{x})-\alpha\Big(1-\frac{L\alpha}{2}\Big)\|\boldsymbol{g}\|_2^2. \tag{5.7}$$

证明　令 $\phi(s)=f(\boldsymbol{x}-s\boldsymbol{g})$。设 $\bar{s}$ 是使 ϕ 在 $[0,\bar{s}]$ 上始终不超过 a 的最大的 $\bar{s}\in[0,\alpha]$，由连续性，这个最大值取得到。因为 $\phi'(0)=-\|\boldsymbol{g}\|_2^2<0$ 且 $\phi(0)\le a$，所以 $\bar{s}>0$。

线段 $\{\boldsymbol{x}-s\boldsymbol{g}:s\in[0,\bar{s}]\}$ 在 $\boldsymbol{S}$ 中，对 $\boldsymbol{p}=-\bar{s}\boldsymbol{g}$ 用下降引理，得到

$$\phi(\bar{s})\le f(\boldsymbol{x})-\bar{s}\Big(1-\frac{L\bar{s}}{2}\Big)\|\boldsymbol{g}\|_2^2<f(\boldsymbol{x})\le a.$$

严格不等式成立，是因为 $0<\bar{s}<2/L$。

若 $\bar{s}<\alpha$，由 $\phi(\bar{s})<a$ 和连续性，ϕ 在 $\bar{s}$ 右侧一小段上仍不超过 a，与 $\bar{s}$ 的取法矛盾。所以 $\bar{s}=\alpha$，上面的不等式就是式 (5.7)。 ■

用 $f(x)=x^4$、$x^{(0)}=1$ 核对一下。取 $a=1$，$\boldsymbol{S}=[-1,1]$，$L=12$，于是 $\alpha<1/6$ 时引理适用。取 $\alpha=1/12$，走到 $x=2/3$，式 (5.7)给出的上界和真实值分别是

$$1-\frac{1}{12}\cdot\frac{1}{2}\cdot 16=\frac{1}{3},\qquad f\Big(\frac{2}{3}\Big)=\frac{16}{81}\approx 0.198.$$

若取 $\alpha=1/2$，超出了范围，迭代在 1 和 -1 之间来回跳，目标不再下降。

目标差控制梯度　式 (5.6)还有一个推论。设 f 在 $\mathbb{R}^n$ 上 L 光滑，并且下有界，记 $f_{\inf}=\inf f$。式 (5.6)的左端不低于 $f_{\inf}$，移项得到

$$\frac{1}{2L}\|\nabla f(\boldsymbol{x})\|_2^2\le f(\boldsymbol{x})-f_{\inf}. \tag{5.8}$$

第 1章在强凸的条件下证过同样的不等式，这里既不要求凸，也不要求二阶可微，甚至不要求最优解存在。直观上，若坡度很陡而离下界很近，沿坡度走一步就会跌破下界。

用 Hessian 估计光滑常数　定义 5.1要比较所有点对，直接检验并不方便。目标二阶可微时，梯度的变化率就是 Hessian，常数可以从 Hessian 读出。

定理 5.4　Hessian 与光滑常数　设 $\boldsymbol{U} \subseteq \mathbb{R}^n$ 是凸开集，f 在 $\boldsymbol{U}$ 上二阶连续可微。则 f 在 $\boldsymbol{U}$ 上 L 光滑，当且仅当对所有 $\boldsymbol{z} \in \boldsymbol{U}$，

$$\|\nabla^2 f(\boldsymbol{z})\|_2 \le L. \tag{5.9}$$

证明　先设式 (5.9)成立。对 $\boldsymbol{u}, \boldsymbol{v} \in \boldsymbol{U}$，线段留在 $\boldsymbol{U}$ 中，这里用到了 $\boldsymbol{U}$ 的凸性。沿线段对梯度积分，得到

$$\nabla f(\boldsymbol{u}) - \nabla f(\boldsymbol{v}) = \int_0^1 \nabla^2 f\big(\boldsymbol{v} + s(\boldsymbol{u}-\boldsymbol{v})\big)(\boldsymbol{u}-\boldsymbol{v})\,\mathrm{d}s.$$

取范数，积分的范数不超过范数的积分，被积向量的范数不超过 $L\|\boldsymbol{u}-\boldsymbol{v}\|_2$，即得式 (5.2)。

反过来，设 f 在 $\boldsymbol{U}$ 上 L 光滑。取 $\boldsymbol{z} \in \boldsymbol{U}$ 和单位向量 $\boldsymbol{v}$，$s>0$ 充分小时 $\boldsymbol{z}+s\boldsymbol{v} \in \boldsymbol{U}$，于是

$$\left\| \frac{\nabla f(\boldsymbol{z}+s\boldsymbol{v}) - \nabla f(\boldsymbol{z})}{s} \right\|_2 \le L.$$

令 $s \downarrow 0$，左端趋于 $\|\nabla^2 f(\boldsymbol{z})\boldsymbol{v}\|_2$。对所有单位向量取上确界，即得式 (5.9)。 ∎

定理说明，最小的光滑常数恰好是 $\boldsymbol{U}$ 上 $\|\nabla^2 f\|_2$ 的上确界。对称矩阵的谱范数等于特征值绝对值的最大者，定义与性质可参考卷二第 6 章“谱分解”。要注意绝对值：负曲率同样计入 L，例如 $\frac{1}{2}(x_1^2 - 4x_2^2)$ 的 $L = 4$。

几个常见情形可以直接写出。二次目标 $\frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{H}\boldsymbol{x}$ 的 $L = \max_i |\lambda_i(\boldsymbol{H})|$，例 (5.1)中 $L = 9$。最小二乘 $\frac{1}{2}\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|_2^2$ 的 Hessian 是 $\boldsymbol{A}^{\top}\boldsymbol{A}$，所以 $L = \|\boldsymbol{A}\|_2^2$。第 1章的二次拟合实例，Hessian 的特征值是 $2+\gamma$ 和 γ，所以 $L = 2+\gamma$。

非二次目标要在整个区域上取上确界。考虑

$$f(\boldsymbol{x}) = \cos(x_1 + x_2) + \frac{1}{2}\|\boldsymbol{x}\|_2^2,$$

记 $c = \cos(x_1+x_2)$，Hessian 是

$$\nabla^2 f(\boldsymbol{x}) = \boldsymbol{I} - c\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.$$

方向 $(1,-1)$ 上的特征值是 1，方向 $(1,1)$ 上的特征值是 $1-2c$。c 取遍 $[-1,1]$ 时，$1-2c$ 取遍 $[-1,3]$，所以 $L = 3$。这个目标在 $c > 1/2$ 的区域非凸，却是全局 3 光滑的。

矩阵太大时怎样估计　维数很大时，特征值不便精确算出。有两类办法，它们的方向相反。第一类给上界，只用矩阵的元素：对称矩阵 $\boldsymbol{H}$ 的谱范数不超过最大的绝对行和 $\|\boldsymbol{H}\|_\infty$，也不超过 Frobenius 范数 $\|\boldsymbol{H}\|_{\mathrm{F}}$；半正定时还不超过迹。第二类给下界：从向量 $\boldsymbol{v}$ 出发反复乘 $\boldsymbol{H}$，这个做法称为幂迭代，再计算 Rayleigh 商 $\boldsymbol{v}^{\top}\boldsymbol{H}\boldsymbol{v}/\boldsymbol{v}^{\top}\boldsymbol{v}$。它不需要写出矩阵，只要能算矩阵向量积。

下面的矩阵用来比较这两类估计：

$$\boldsymbol{H} = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 2 \end{bmatrix}.$$

它的特征值是 $1, 2, 4$，所以 $L = 4$。三个上界分别是

$$\|\boldsymbol{H}\|_\infty = 5, \qquad \|\boldsymbol{H}\|_{\mathrm{F}} = \sqrt{21} \approx 4.58, \qquad \operatorname{tr}\boldsymbol{H} = 7.$$

幂迭代从 $\boldsymbol{v} = (1, 1, 1)$ 出发，前三次的 Rayleigh 商是

$$\frac{11}{3} \approx 3.667, \qquad \frac{171}{43} \approx 3.977, \qquad \frac{2731}{683} \approx 3.999.$$

图 5.5把两类估计放在一起。上界偏保守，用它得到的步长偏小，但步长是安全的。幂迭代逼近得快，却总从下方接近真值，直接拿来算步长可能略微超出安全范围。实践中常把幂迭代的结果乘一个略大于 1 的系数。

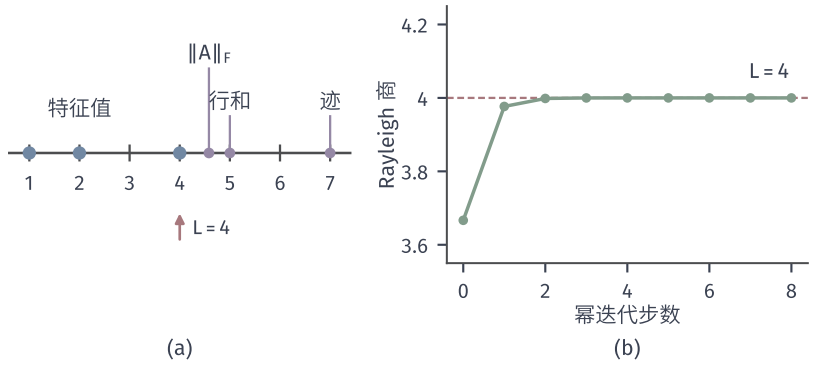


图 5.5　估计 L 的两类办法，矩阵见正文，特征值为 $1, 2, 4$。(a) 数轴上的蓝点是特征值，紫点是由元素算出的三个上界：Frobenius 范数约 4.58、最大绝对行和 5、迹 7，它们都不低于 $L = 4$。(b) 幂迭代的 Rayleigh 商随步数增加，始终不超过 L（红色虚线）。

对非二次目标，还要处理 $\boldsymbol{z}$ 变化带来的麻烦：在一点上的估计并不代表整个区域。下一节的回溯线搜索正是为不知道 L 的情形准备的，它把估计常数换成了用真实函数值检验。

5.2 步长的选择

5.1 光滑性
5.2 步长的选择
5.2.1 固定步长
5.2.2 回溯线搜索
5.2.3 Wolfe 条件
5.3 求解误差与计算成本
5.4 本章小结

现在固定当前点 $\boldsymbol{x}$ 和一个下降方向 $\boldsymbol{d}$，只决定走多远。记 $\boldsymbol{g}=\nabla f(\boldsymbol{x})$，并把目标限制到这条射线上：

$$\phi(\alpha)=f(\boldsymbol{x}+\alpha\boldsymbol{d}),\qquad \alpha\ge 0. \tag{5.10}$$

由链式法则，

$$\phi'(\alpha)=\langle\nabla f(\boldsymbol{x}+\alpha\boldsymbol{d}),\boldsymbol{d}\rangle,\qquad \phi'(0)=\langle\boldsymbol{g},\boldsymbol{d}\rangle<0.$$

候选步长满足什么条件，就可以接受？这个问题有三种回答，区别在于事先要知道什么、每一步要多算什么。固定步长事先靠 L 定好，运行时什么也不检验。回溯线搜索不需要 L，用函数值检验每个候选。Wolfe 条件再加上对方向导数的检验，换来更强的保证。

在二次目标上，ϕ 是一条抛物线，三种规则都可以写成步长的区间。设 $f(\boldsymbol{x})=\frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{H}\boldsymbol{x}$，$\boldsymbol{H}$ 对称正定，$\langle\boldsymbol{d},\boldsymbol{H}\boldsymbol{d}\rangle>0$。将 ϕ 展开，得到

$$\phi(\alpha)=\phi(0)+\alpha\phi'(0)+\frac{\alpha^2}{2}\langle\boldsymbol{d},\boldsymbol{H}\boldsymbol{d}\rangle.$$

它的最低点记作

$$\alpha_{\mathrm{e}}=\frac{-\phi'(0)}{\langle\boldsymbol{d},\boldsymbol{H}\boldsymbol{d}\rangle}. \tag{5.11}$$

用 α_{e} 改写，后面反复要用的两个式子是

$$\begin{aligned}\phi(\alpha)&=\phi(0)+\alpha\phi'(0)\Big(1-\frac{\alpha}{2\alpha_{\mathrm{e}}}\Big),\\ \phi'(\alpha)&=\phi'(0)\Big(1-\frac{\alpha}{\alpha_{\mathrm{e}}}\Big).\end{aligned} \tag{5.12}$$

例 (5.1)从 $\boldsymbol{x}^{(0)}$ 沿 $\boldsymbol{d}=-\boldsymbol{g}^{(0)}=(-9,-9)$ 走时，下面三个数在本节一直用到：

$$\phi'(0)=-162,\qquad \langle\boldsymbol{d},\boldsymbol{H}\boldsymbol{d}\rangle=810,\qquad \alpha_{\mathrm{e}}=\frac{1}{5}.$$

这条线上的目标是

$$\phi(\alpha)=45-162\alpha+405\alpha^2.$$

5.2.1 固定步长

负梯度方向　先看最简单的情形：$\boldsymbol{d}=-\boldsymbol{g}$，步长是事先定好的常数。在下降引理 (5.4)中取 $\boldsymbol{p}=-\alpha\boldsymbol{g}$，得到

$$f(\boldsymbol{x}-\alpha\boldsymbol{g})\le f(\boldsymbol{x})-\alpha\Big(1-\frac{L\alpha}{2}\Big)\|\boldsymbol{g}\|_2^2. \tag{5.13}$$

括号前的 α 是沿坡度得到的收益，括号里的 $L\alpha/2$ 是弯曲带来的折扣。只要 $0 < \alpha < 2/L$，保证的下降量就是正的。保证的下降量是 α 的二次函数，在 $\alpha = 1/L$ 处最大，值为 $\|\boldsymbol{g}\|_2^2/(2L)$，这就是式 (5.6)。

图 5.6在例 (5.1)上比较上界与真实目标。$L = 9$，$\|\boldsymbol{g}^{(0)}\|_2^2 = 162$，上界是

$$45 - 162\alpha + 729\alpha^2.$$

取 $\alpha = 1/L = 1/9$ 时，上界为 36，真实值为 32。上界在 $\alpha = 2/L$ 处回到 45，真实目标却要到 $\alpha = 0.4$ 才回到 45。

这个差别来自方向。这条线上目标的曲率是 $810/162 = 5$，小于最坏方向的 9。所以 $2/L$ 并不是这个方向上真实的界限，而是对所有点、所有方向都安全的界限。

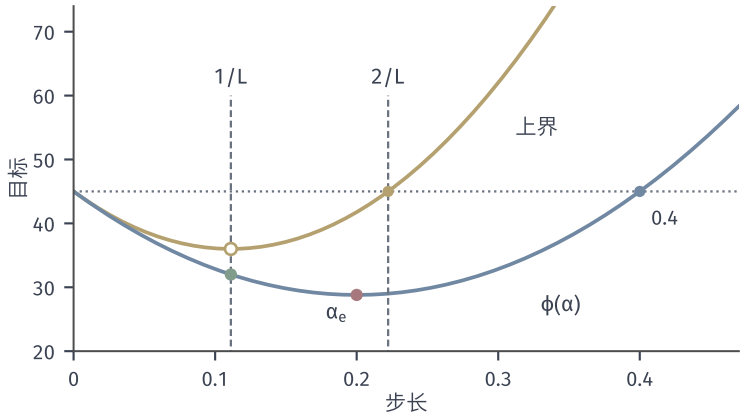


图 5.6　沿负梯度的一维剖面，例 (5.1)，$\boldsymbol{x}^{(0)} = (9, 1)$。蓝线是真实的 $\phi(\alpha)$，黄线是下降引理的上界，点线是当前高度 45。上界的最低点在 $1/L$，回到 45 的位置是 $2/L$；真实目标的最低点是红点 $\alpha_e = 0.2$，回到 45 的位置是 0.4。绿点是 $\alpha = 1/L$ 时的真实值，它低于同一步长的上界值（空心点）。

界限 $2/L$ 在最坏方向上是紧的　一元二次目标 $f(x) = \frac{L}{2}x^2$ 说明，范围不能放宽。更新 $x^+ = x - \alpha L x = (1 - \alpha L)x$，乘数的绝对值小于 1 当且仅当 $0 < \alpha < 2/L$。$\alpha = 2/L$ 时乘数是 -1，迭代来回跳；$\alpha > 2/L$ 时迭代发散。

对二次目标，每个特征方向各自按这个规律变化。例 (5.1)中 $\boldsymbol{H}$ 是对角阵，固定步长的迭代逐分量写出来是

$$x_1^{(t+1)} = (1 - \alpha)x_1^{(t)}, \qquad x_2^{(t+1)} = (1 - 9\alpha)x_2^{(t)}.$$

图 5.7比较三个步长。$\alpha = 1/9$ 时第二个乘数为零，一步消去最陡的分量，此后沿平坦方向每步只缩小到 $8/9$。$\alpha = 1/5$ 时两个乘数是 0.8 和 -0.8，大小相同，路径锯齿前进。$\alpha = 1/4$ 超过了 $2/L = 2/9$，第二个乘数是 -1.25，x_2 振荡发散。

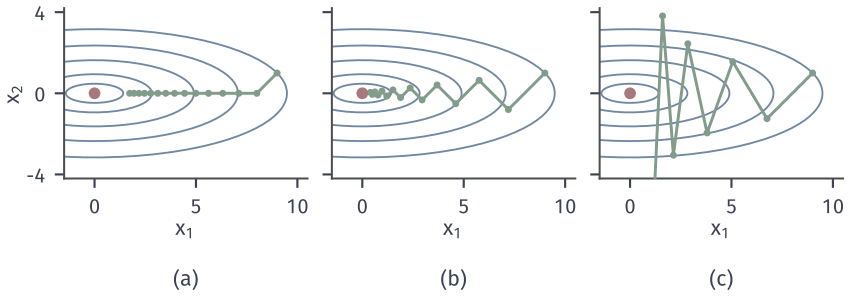


图 5.7 例 (5.1)上固定步长的梯度下降路径，绿点是迭代点，红点是最优解。(a)$\alpha = 1/9$，乘数为 8/9 和 0。(b)$\alpha = 1/5$，乘数为 0.8 和 -0.8。(c)$\alpha = 1/4 > 2/L$，乘数为 0.75 和 -1.25，路径沿 x_2 方向越摆越大。

已知上界时怎样选 若手里有一个上界 $\hat{L} \geq L$，取 $\alpha = 1/\hat{L}$ 总是安全的。代入式 (5.13)，并用 $L/\hat{L} \leq 1$，得到

$$f(\boldsymbol{x}) - f(\boldsymbol{x} - \alpha \boldsymbol{g}) \geq \frac{1}{2\hat{L}} \|\boldsymbol{g}\|_2^2.$$

上界放大几倍，保证的下降量就缩小几倍，这是高估的代价。低估的代价可能更严重：$\hat{L} < L/2$ 时 $\alpha > 2/L$，最坏方向上会发散。例 (5.1)若误取 $\hat{L} = 4$，得到的恰是图 5.7(c)。

固定步长的运行过程只有一步：算梯度，走 α，再算梯度。它每轮只读一次梯度，不计算函数值，也不做任何检验，这是它最大的优点。目标只在下水平集上有常数时，引理 5.3说明用 $\boldsymbol{S} = \{f \leq f(\boldsymbol{x}^{(0)})\}$ 上的 L 就够了；每步下降保证迭代留在 $\boldsymbol{S}$ 内，同一个常数可以一直用。

一般下降方向 后面各章的方向不一定是负梯度，上面的区间不能照搬。在下降引理中取 $\boldsymbol{p} = \alpha \boldsymbol{d}$，得到

$$f(\boldsymbol{x} + \alpha \boldsymbol{d}) \leq f(\boldsymbol{x}) + \alpha \langle \boldsymbol{g}, \boldsymbol{d} \rangle + \frac{L\alpha^2}{2} \|\boldsymbol{d}\|_2^2. \tag{5.14}$$

右端是 α 的二次函数。它低于 $f(\boldsymbol{x})$ 的范围、取最小值的步长分别是

$$0 < \alpha < \frac{2|\langle \boldsymbol{g}, \boldsymbol{d} \rangle|}{L\|\boldsymbol{d}\|_2^2}, \qquad \alpha = \frac{|\langle \boldsymbol{g}, \boldsymbol{d} \rangle|}{L\|\boldsymbol{d}\|_2^2}. \tag{5.15}$$

代入后，一步保证的下降量可以用 $\boldsymbol{d}$ 与 $-\boldsymbol{g}$ 的夹角 θ 表示：

$$\frac{\langle \boldsymbol{g}, \boldsymbol{d} \rangle^2}{2L\|\boldsymbol{d}\|_2^2} = \frac{\cos^2\theta}{2L} \|\boldsymbol{g}\|_2^2, \qquad \cos\theta = \frac{|\langle \boldsymbol{g}, \boldsymbol{d} \rangle|}{\|\boldsymbol{g}\|_2 \|\boldsymbol{d}\|_2}. \tag{5.16}$$

式 (5.15)含有方向的长度和方向导数，这两点都有具体后果。先看长度。把方向放大 10 倍，$\boldsymbol{d} = -10\boldsymbol{g}^{(0)}$，再取 $\alpha = 1/L = 1/9$，实际位移是 $-\frac{10}{9}\boldsymbol{g}^{(0)}$，于是

$$\boldsymbol{x}^{(1)} = (9,1) - 10(1,1) = (-1,-9), \qquad f(\boldsymbol{x}^{(1)}) = 365.$$

目标从 45 涨到 365。图 5.8(a) 的虚线正是这种情形。步长的单位包含了方向的长度，$1/L$ 只适用于 $\boldsymbol{d} = -\boldsymbol{g}$ 这一个尺度。

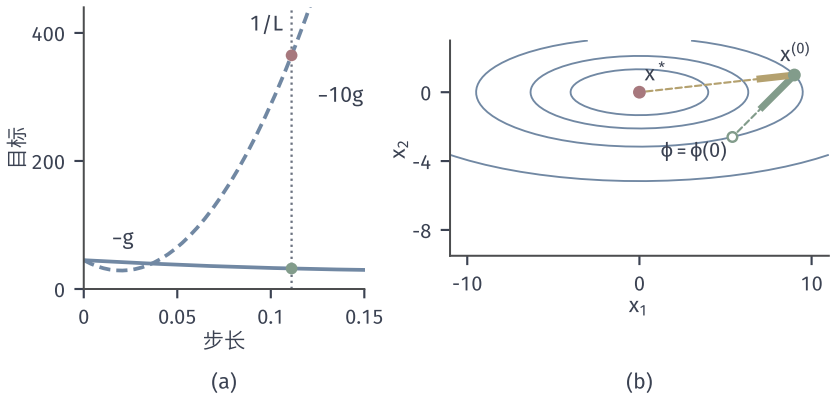


图 5.8　一般方向不能照搬 $\alpha < 2/L$。(a) 沿 $-\boldsymbol{g}$（实线）与 $-10\boldsymbol{g}$（虚线）的目标剖面，同样取 $\alpha = 1/L$，前者到 32，后者到 365。(b) 从 $\boldsymbol{x}^{(0)}$ 出发的两个方向：绿色 $-\boldsymbol{g}$，黄色 $-\boldsymbol{H}^{-1}\boldsymbol{g}$。粗线段是式 (5.15)保证下降的范围，虚线延伸到真实目标回到起始高度或到达最低点的位置。

再看方向导数。取 $\boldsymbol{d} = (-1, 0.9)$，它几乎贴着等高线，$\langle \boldsymbol{g}^{(0)}, \boldsymbol{d} \rangle = -0.9$，$\|\boldsymbol{d}\|_2^2 = 1.81$，由式 (5.16)，保证的下降量是

$$\frac{0.81}{2 \cdot 9 \cdot 1.81} \approx 0.025,$$

而负梯度方向是 9。方向虽然严格下降，贴着等高线走，保证的进展几乎没有。

第三个例子说明上界有时过于悲观。$\boldsymbol{d} = -\boldsymbol{H}^{-1}\boldsymbol{g}^{(0)} = (-9,-1)$ 时，式 (5.15)的范围是

$$0 < \alpha < \frac{2 \cdot 90}{9 \cdot 82} \approx 0.244.$$

但这个方向直指最优解，$\alpha = 1$ 一步到位。上界用的是最陡方向的曲率 9，这条线上的实际曲率却只有

$$\frac{\langle \boldsymbol{d}, \boldsymbol{H}\boldsymbol{d} \rangle}{\|\boldsymbol{d}\|_2^2} = \frac{90}{82} \approx 1.1.$$

图 5.8(b) 的黄色粗线段远短于黄色虚线，差的就是这个比值。

这三个例子都说明，固定步长依赖对 L 和方向尺度的先验知识。下一小节改用实际目标值检验候选。

5.1 光滑性
5.2 步长的选择
5.2.1 固定步长
5.2.2 回溯线搜索
5.2.3 Wolfe 条件
5.3 求解误差与计算成本
5.4 本章小结

5.2.2 回溯线搜索

主要思想 不知道 L 时，不妨先迈一大步，看看真实高度是否令人满意；不满意就退回来，迈小一些。这里的关键是“满意”的标准。只要求 $\phi(\alpha)<\phi(0)$ 是不够的，后面会看到，这样的下降可能小到不产生进展。

合理的标准是把实际下降与一阶预测比较。走 α 时，线性预测的下降量是 $-\alpha\phi'(0)$。我们要求实际下降不少于预测的固定比例。这和记账相似：线性预测是承诺的收益，实际下降是到账的收益，至少到账一定比例才算数。

定义 5.5 Armijo 条件 设 $\langle \boldsymbol{g},\boldsymbol{d}\rangle<0$，$c_1\in(0,1)$。若步长 $\alpha>0$ 满足

$$f(\boldsymbol{x}+\alpha\boldsymbol{d})\le f(\boldsymbol{x})+c_1\alpha\langle \boldsymbol{g},\boldsymbol{d}\rangle, \tag{5.17}$$

就说它满足Armijo 条件（Armijo condition），也称充分下降条件（sufficient decrease condition）。

条件的右端是从 $(0,\phi(0))$ 出发、斜率为 $c_1\phi'(0)$ 的直线，它比切线平缓。Armijo 条件要求曲线落在这条直线下方。c_1 的两个端点都不能取：$c_1=0$ 退化成只要求下降，$c_1=1$ 时直线就是切线，而凸的 ϕ 永远不低于切线，没有步长可以通过。实践中常取很小的值，如 $c_1=10^{-4}$[1]。

由式 (5.12)，二次目标上的 Armijo 条件化为 $1-\alpha/(2\alpha_{\mathrm{e}})\ge c_1$，也就是

$$0<\alpha\le 2(1-c_1)\alpha_{\mathrm{e}}. \tag{5.18}$$

例中取 $c_1=0.1$，可接受的步长是 $(0,0.36]$，如图 5.9中的绿色线段。

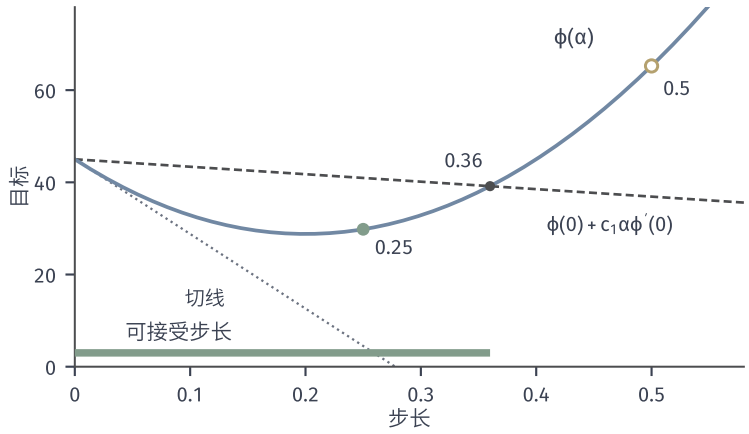


图 5.9 Armijo 条件，例 (5.1)第一轮，$c_1=0.1$。蓝线是 $\phi(\alpha)$，点线是切线，深灰虚线是斜率为 $c_1\phi'(0)$ 的检验直线，曲线在它下方的步长（绿色线段）$(0,0.36]$ 可接受。回溯从 $\alpha=1$ 开始（$\phi(1)=288$，在图外），$\alpha=0.5$ 被拒绝（空心点），$\alpha=0.25$ 通过（绿点）。

[1] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

这样的做法称为**回溯线搜索**（backtracking line search）：从初始试探步长 α_0 开始，不满足式 (5.17)就乘以缩减因子 $\rho \in (0,1)$，第一个通过的步长就是结果。下面的定理回答这个过程为什么会停，以及停在多大的步长上。

定理 5.6　回溯的终止与步长下界　设 f 在 $\boldsymbol{x}$ 处可微，$\langle \boldsymbol{g}, \boldsymbol{d} \rangle < 0$，$c_1, \rho \in (0,1)$，$\alpha_0 > 0$。则回溯经有限次试探后终止。

进一步设 ∇f 在线段 $\{\boldsymbol{x} + s\boldsymbol{d} : s \in [0, \alpha_0]\}$ 上以常数 $L > 0$ 满足式 (5.2)，并记

$$\bar{\alpha} = \frac{2(1-c_1)|\langle \boldsymbol{g}, \boldsymbol{d} \rangle|}{L \|\boldsymbol{d}\|_2^2}. \tag{5.19}$$

则 $(0, \alpha_0]$ 中不超过 $\bar{\alpha}$ 的步长都满足 Armijo 条件，接受的步长 α 和试探次数 n 满足

$$\alpha \geq \min\{\alpha_0, \rho\bar{\alpha}\}, \qquad n \leq 1 + \left\lceil \log_{1/\rho} \frac{\alpha_0}{\bar{\alpha}} \right\rceil_+, \tag{5.20}$$

其中 $\lceil a \rceil_+ = \max\{\lceil a \rceil, 0\}$。一步的下降量满足

$$f(\boldsymbol{x}) - f(\boldsymbol{x} + \alpha\boldsymbol{d}) \geq c_1 \min\{\alpha_0, \rho\bar{\alpha}\} |\langle \boldsymbol{g}, \boldsymbol{d} \rangle|. \tag{5.21}$$

证明　先证终止。由可微性，当 $\alpha \downarrow 0$ 时

$$\frac{\phi(\alpha) - \phi(0)}{\alpha} \to \phi'(0).$$

因为 $\phi'(0) < 0$ 且 $c_1 < 1$，所以 $\phi'(0) < c_1 \phi'(0)$。于是存在 $\alpha' > 0$，使 $\alpha \in (0, \alpha']$ 时差商小于 $c_1\phi'(0)$，这正是式 (5.17)。试探步长 $\alpha_0 \rho^j$ 趋于零，有限步后落入 $(0, \alpha']$。

再证定量部分。设 $\alpha \in (0, \alpha_0]$，$\alpha \leq \bar{\alpha}$。线段上的 Lipschitz 条件使式 (5.14)成立。由 $\alpha \leq \bar{\alpha}$ 得到

$$\frac{L\alpha}{2} \|\boldsymbol{d}\|_2^2 \leq (1-c_1) |\langle \boldsymbol{g}, \boldsymbol{d} \rangle|.$$

代入式 (5.14)的最后一项，得到

$$f(\boldsymbol{x} + \alpha\boldsymbol{d}) \leq f(\boldsymbol{x}) + \alpha\langle \boldsymbol{g}, \boldsymbol{d} \rangle + \alpha(1-c_1)|\langle \boldsymbol{g}, \boldsymbol{d} \rangle|.$$

由 $\langle \boldsymbol{g}, \boldsymbol{d} \rangle < 0$，右端等于式 (5.17)的右端。

若 α_0 直接通过，则 $\alpha = \alpha_0$。否则，被接受步长的上一次试探 α/ρ 未通过，由刚证的结论 $\alpha/\rho > \bar{\alpha}$，所以 $\alpha > \rho\bar{\alpha}$。这得到步长下界。

> 第 j 次试探的步长是 $\alpha_0\rho^{j-1}$，它一旦不超过 $\bar{\alpha}$ 就一定通过，这要求 $j-1 \ge \log_{1/\rho}(\alpha_0/\bar{\alpha})$，试探次数的上界由此得出。把步长下界代入式 (5.17)，即得式 (5.21)。 ∎

定理中各条件的作用可以分开看。下降方向是必需的：若 $\phi'(0) > 0$，式 (5.17)对所有充分小的 α 都不成立，回溯不会在小步长上停下来。终止只用到当前点的可微性，算法也不需要知道 L。L 只出现在分析里，用来定量说明步长不会太小。

这里的 L 只要覆盖试探过的线段，这就是局部光滑性足够的原因。取 $f(x)=x^4$，它没有全局的 L，从 $x=1.5$ 出发，$d=-13.5$，$c_1=0.1$，$\rho=1/2$，$\alpha_0=1$。试探点和目标值依次是

$$\begin{aligned}
&\alpha=1: && x=-12, && f=20736,\\
&\alpha=\tfrac{1}{2}: && x=-5.25, && f\approx 759.7,\\
&\alpha=\tfrac{1}{4}: && x=-1.875, && f\approx 12.36,\\
&\alpha=\tfrac{1}{8}: && x=-0.1875, && f\approx 0.0012.
\end{aligned}$$

最后一次的右端是 $5.0625-0.1\cdot\frac{1}{8}\cdot 182.25\approx 2.78$，条件满足。用固定步长时必须事先想清楚区域和常数，回溯把这些问题都交给了实际的函数值。

计算过程　下面用例 (5.1)走一遍，方向取负梯度，这也是下一章梯度下降法使用的形式。

变量

- $\boldsymbol{x}\in\mathbb{R}^n$：当前点；$\boldsymbol{g}\in\mathbb{R}^n$：当前梯度；$\boldsymbol{d}\in\mathbb{R}^n$：方向。
- f_{cur}：当前目标值；$\sigma=\langle \boldsymbol{g},\boldsymbol{d}\rangle$：方向导数，是一个负数。
- α：当前试探步长；c_1,ρ,α_0：Armijo 常数、缩减因子、初始试探步长。
- ε：梯度容差。

初始化　取定初始点，算出它的目标值和梯度。例中 $\boldsymbol{x}=(9,1)$，参数和初值是

$$c_1=0.1,\quad \rho=0.5,\quad \alpha_0=1,\quad \varepsilon=10^{-3},$$

$$f_{\mathrm{cur}}=45,\quad \boldsymbol{g}=(9,9).$$

每轮更新

1. 计算方向 $\boldsymbol{d} = -\boldsymbol{g}$ 和方向导数 $\sigma = -\|\boldsymbol{g}\|_2^2$。令 $\alpha \leftarrow \alpha_0$。

   例中第一轮 $\boldsymbol{d} = (-9, -9)$，$\sigma = -162$，$\alpha = 1$。

2. 计算试探点 $\boldsymbol{x} + \alpha\boldsymbol{d}$ 及其目标值，按式 (5.17)与 $f_{\text{cur}} + c_1\alpha\sigma$ 比较。不满足就令 $\alpha \leftarrow \rho\alpha$，重复这一步。

   例中第一轮的三次试探依次是

$$\begin{aligned} \alpha = 1 &: \quad (0, -8), \quad f = 288 > 28.8, \\ \alpha = 0.5 &: \quad (4.5, -3.5), \quad f = 65.25 > 36.9, \\ \alpha = 0.25 &: \quad (6.75, -1.25), \quad f = 29.8125 \le 40.95. \end{aligned}$$

   第三次通过。

3. 接受试探点，更新 $\boldsymbol{x}$、f_{cur}，计算新梯度。

   例中得到

$$\boldsymbol{x} = (6.75, -1.25), \quad f_{\text{cur}} = 29.8125, \quad \boldsymbol{g} = (6.75, -11.25).$$

4. 若 $\|\boldsymbol{g}\|_2 \le \varepsilon$，停止；否则回到第 1 步。

   例中 $\|\boldsymbol{g}\|_2 \approx 13.12$，继续。第二轮 $\sigma = -172.125$，试探如下：

$$\begin{aligned} \alpha = 1 &: \quad (0, 10), \quad f = 450 > 12.6, \\ \alpha = 0.5 &: \quad (3.375, 4.375), \quad f \approx 91.83 > 21.21, \\ \alpha = 0.25 &: \quad (5.0625, 1.5625), \quad f \approx 23.80 \le 25.51. \end{aligned}$$

后面几轮的结果列在表 5.2中，路径见图 5.10。第一轮接受的 0.25 超过了固定步长的安全上限 $2/L = 2/9$，这正是检验真实函数值带来的好处。

t	$x_1^{(t)}$	$x_2^{(t)}$	$f(\boldsymbol{x}^{(t)})$	$\|\boldsymbol{g}^{(t)}\|_2$	试探次数	$\alpha^{(t)}$
0	9.000	1.000	45.000	12.728	3	0.25
1	6.750	−1.250	29.813	13.120	3	0.25
2	5.063	1.563	23.801	14.946	4	0.125
3	4.430	−0.195	9.983	4.766	2	0.5
4	2.215	0.684	4.556	6.539	4	0.125
5	1.938	−0.085	1.911	2.085	2	0.5
6	0.969	0.299	0.872	2.861	4	0.125

表 5.2　例 (5.1)上负梯度方向的回溯，$c_1 = 0.1$，$\rho = 0.5$，$\alpha_0 = 1$。每行是该轮开始时的点，以及该轮的试探次数与接受的步长。

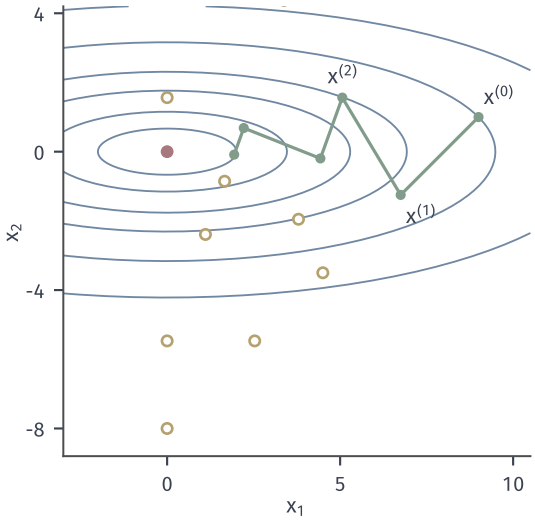


图 5.10 回溯的路径。绿点和绿线是前五轮接受的点，黄色空心点是这几轮被拒绝的试探点，它们都落在比当前点差得多的位置，超出图幅的未画出。目标见例 (5.1)，参数同表 5.2。

从 $t=3$ 起步长在 0.5 与 0.125 之间交替：沿平坦方向时能迈大步，碰到陡峭分量时又缩回来。迭代在 $\|\boldsymbol{g}\|_2 \le 10^{-3}$ 时结束，共 25 轮、76 次试探。最终得到

$$\boldsymbol{x}^{(25)} \approx (4.98\times10^{-4},\ -2.2\times10^{-5}), \qquad f(\boldsymbol{x}^{(25)}) \approx 1.3\times10^{-7}.$$

每次试探增加的函数计算 回溯的代价是被拒绝的试探。一轮共试探 n 次，就多算 n 次函数值。由式 (5.20)，例中第一轮的 $\bar\alpha = 0.2$，试探次数的上界是 $1+\lceil \log_2 5\rceil = 4$，实际是 3 次。

每轮都从同一个 α_0 开始，就要反复支付同样的试探。一个自然的办法是用上一轮接受的步长作起点，也就是 $\alpha_0^{(t+1)} = \alpha^{(t)}$。这时步长不增，设 ∇f 全局 L 光滑、方向为负梯度，则每次拒绝都发生在 $\alpha > \bar\alpha = 2(1-c_1)/L$ 的步长上。每次拒绝让步长缩小 ρ 倍，所以全程被拒绝的总次数 R 满足

$$R \le 1 + \log_{1/\rho} \frac{\alpha_0 L}{2(1-c_1)}. \tag{5.22}$$

这样，函数计算的总次数是 $T+R$，也就是只比轮数多一个对数项。例中上界约是 3.3，全程实际拒绝 3 次。

但是步长只减不增，走到平坦的区域也不能放大。折中的办法是每轮把初值放大 $1/\rho$ 倍。取 $\rho = 1/2$ 时，第 t 轮被拒绝 r_t 次，步长变化是

$$\alpha^{(t+1)} = 2\cdot 2^{-r_{t+1}}\alpha^{(t)}.$$

5.1 光滑性
5.2 步长的选择
5.2.1 固定步长
5.2.2 回溯线搜索
5.2.3 Wolfe 条件
5.3 求解误差与计算成本
5.4 本章小结

累加后，只要步长有正的下界，$\sum_t r_t$ 至多比 T 多一个常数，所以每轮平均约试探两次。图 5.11中，每轮从 1 开始时平均 3.04 次，放大策略平均 2.06 次。

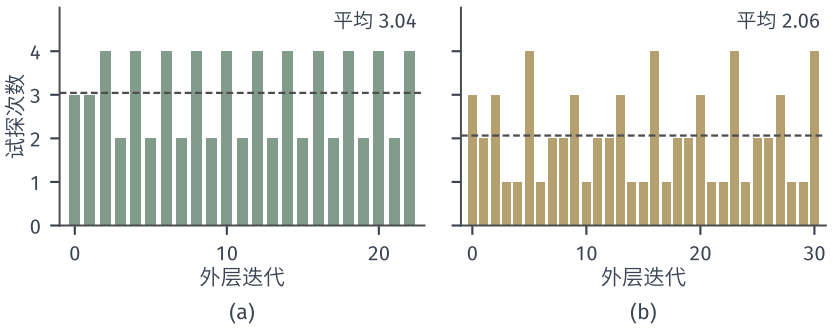


图 5.11 每轮的试探次数，直到目标差不超过 10^{-6}，目标见例 (5.1)。(a) 每轮都从 $\alpha_0 = 1$ 开始，共 23 轮、70 次试探。(b) 每轮的初值取上一轮接受步长的 2 倍，共 31 轮、64 次试探。虚线是平均值。

试探的单价也可以压低。例如最小二乘 $\frac{1}{2}\|\boldsymbol{Ax}-\boldsymbol{b}\|_2^2$，只要算一次 $\boldsymbol{Ad}$，每个候选的目标值就是 $\frac{1}{2}\|\boldsymbol{r}+\alpha\boldsymbol{Ad}\|_2^2$，其中 $\boldsymbol{r}=\boldsymbol{Ax}-\boldsymbol{b}$，只需向量运算。通过的试探点的函数值和部分中间量也常能在计算下一轮梯度时复用。

5.2.3 Wolfe 条件

只看函数值挡不住太小的步长 Armijo 条件只限制步长不能太大，太小的步长总能通过。回溯之所以没有这个问题，是因为被接受的步长的上一次试探失败过，α 不会比门槛小太多。可一旦步长不是由回溯产生，比如来自插值或其他公式，这层保护就没有了。

下面的例子中，每一步都满足 Armijo 条件，迭代却停在非驻点。取 $f(x)=x^2$，方向恒为 $d=-1$，步长 $\alpha^{(t)}=2^{-t-1}$，于是

$$x^{(t)} = 1 + 2^{-t} \to 1.$$

一步的实际下降量和预测下降量分别是

$$2^{-t-1}\bigl(2+3\cdot 2^{-t-1}\bigr), \qquad 2^{-t-1}\bigl(2+2^{1-t}\bigr).$$

括号比较可知，$c_1 \le 3/4$ 时 Armijo 条件每一步都成立。但极限点 $x=1$ 处 $f'(1)=2\neq 0$，迭代不是因为到了谷底才停下，只是步子缩得太快。图 5.12(a) 画出了这个序列。

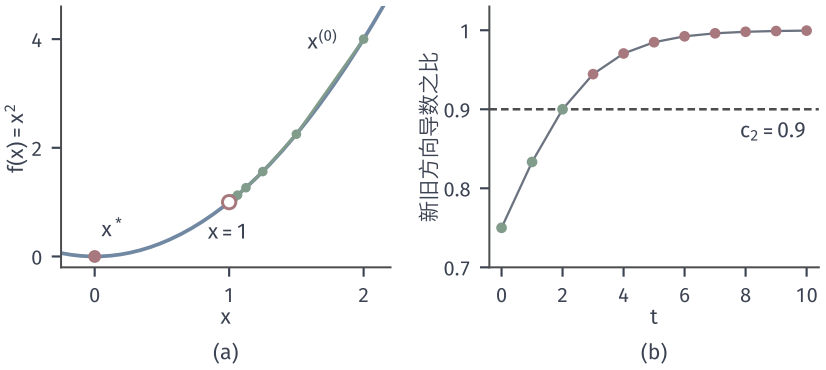


图 5.12 只满足 Armijo 条件的序列可能停在非驻点。(a)$f(x) = x^2$ 上的序列 $x^{(t)} = 1 + 2^{-t}$（绿点），收敛到空心红点 $x = 1$，真正的最优解是实心红点。(b) 每步新旧方向导数之比。比值超过虚线 $c_2 = 0.9$ 的点（红色）不满足曲率条件。

用斜率判断“还能走” 步子太短的后果，可以从落脚点的坡度看出来。如果落脚后 $\phi'(\alpha)$ 仍然和 $\phi'(0)$ 差不多陡，说明继续往前走还有几乎同样的下降率，停下来可惜。反之，坡度已经明显变缓甚至变正，才说明这段路的收益基本取尽了。用上面的例子算比值：

$$\frac{\phi'(\alpha^{(t)})}{\phi'(0)} = \frac{2 + 2^{-t}}{2 + 2^{1-t}} \to 1.$$

落脚点的坡度几乎不变，这正是步长太短的标志，见图 5.12(b)。

定义 5.7 Wolfe 条件 设 $\langle \boldsymbol{g}, \boldsymbol{d} \rangle < 0$，$0 < c_1 < c_2 < 1$。若 $\alpha > 0$ 满足 Armijo 条件 (5.17)和

$$\langle \nabla f(\boldsymbol{x} + \alpha \boldsymbol{d}), \boldsymbol{d} \rangle \geq c_2 \langle \boldsymbol{g}, \boldsymbol{d} \rangle, \tag{5.23}$$

就说它满足Wolfe 条件（Wolfe conditions）；式 (5.23)单独称为曲率条件（curvature condition）。若把式 (5.23)换成

$$\left| \langle \nabla f(\boldsymbol{x} + \alpha \boldsymbol{d}), \boldsymbol{d} \rangle \right| \leq c_2 |\langle \boldsymbol{g}, \boldsymbol{d} \rangle|, \tag{5.24}$$

就说它满足强 Wolfe 条件（strong Wolfe conditions）。

曲率条件只限制方向导数不能太负，也就是挡住太短的步长；Armijo 条件挡住太长的步长；两者一上一下。强条件还限制方向导数不能太正，因而在最低点附近形成一个窗口。

在二次目标上，由式 (5.12)，方向导数之比是 $1-\alpha/\alpha_{\mathrm{e}}$，两种条件的区间可以直接写出：

$$\begin{aligned} &\text{Wolfe:} && (1-c_2)\alpha_{\mathrm{e}} \le \alpha \le 2(1-c_1)\alpha_{\mathrm{e}}, \\ &\text{强 Wolfe:} && (1-c_2)\alpha_{\mathrm{e}} \le \alpha \le \min\{1+c_2,\, 2(1-c_1)\}\alpha_{\mathrm{e}}. \end{aligned} \tag{5.25}$$

例 (5.1)第一轮，$\alpha_{\mathrm{e}}=0.2$，取 $c_1=0.1$，$c_2=0.5$。Wolfe 区间是 $[0.1, 0.36]$，强 Wolfe 区间是 $[0.1, 0.3]$。代入三个候选步长检验，其中 $c_2\phi'(0)=-81$：

$$\begin{aligned} &\alpha=0.05: && \phi'=-121.5<-81, \text{ 太短，不通过;} \\ &\alpha=0.25: && \phi'=40.5, \text{ 两种条件都通过;} \\ &\alpha=0.33: && \phi'=105.3, \text{ Wolfe 通过，强 Wolfe 不通过.} \end{aligned}$$

图 5.13换了一个非凸的一元剖面。Armijo 条件的可接受集是一个长区间；加上曲率条件后，靠近 0 的太短步长被去掉；强条件再去掉斜率太大的部分，只留下每个谷底、谷间凸起附近的小窗口。这里的窗口不止一个，线搜索只需要落进其中之一。

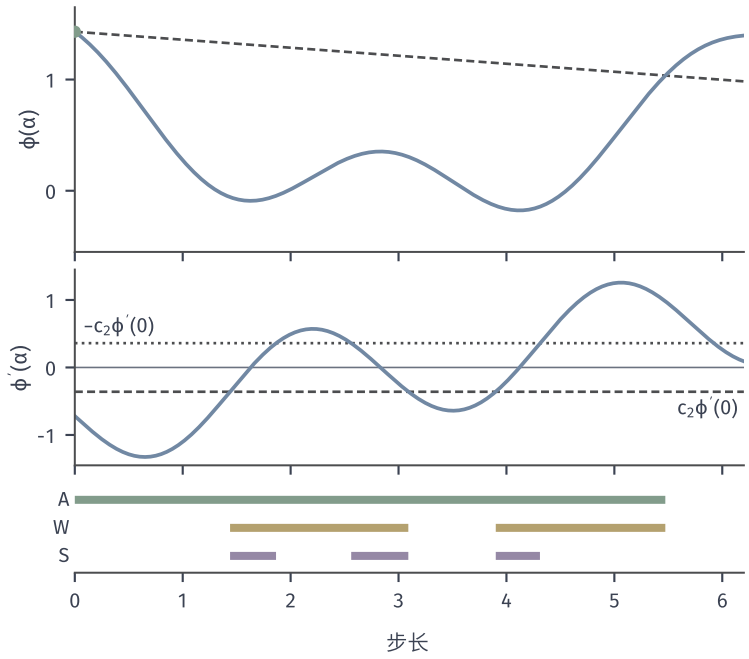


图 5.13　非凸剖面 $\phi(\alpha)=0.12(\alpha-3)^2+0.35\cos(2.2\alpha)$ 上的可接受步长，$c_1=0.1$，$c_2=0.5$。上图虚线是 Armijo 检验直线，中图的虚线和点线是 $\pm c_2\phi'(0)$。下方三条：A 是满足 Armijo 条件的步长，W 是满足 Wolfe 条件的步长，S 是满足强 Wolfe 条件的步长。

满足条件的步长存在 要使用这些条件，先要确认可接受的步长总是存在。需要的额外假设是 ϕ 有下界；否则沿这条线可以无限下降，不存在要停下的理由。

定理 5.8 Wolfe 步长的存在 设 f 连续可微，$\langle \boldsymbol{g}, \boldsymbol{d} \rangle < 0$，$\phi$ 在 $[0, \infty)$ 上有下界，$0 < c_1 < c_2 < 1$。则存在一个开区间，其中每个步长都满足强 Wolfe 条件，因而也满足 Wolfe 条件。

证明 直线 $\ell(\alpha) = \phi(0) + c_1 \alpha \phi'(0)$ 无下界，而 ϕ 有下界，所以两者在某个正步长相交。因 $\phi'(0) < c_1 \phi'(0)$，α 很小时 $\phi < \ell$。记最小的正交点为 α'，于是在 $(0, \alpha')$ 上 $\phi < \ell$。

由微分中值定理，存在 $\alpha'' \in (0, \alpha')$，使

$$\phi'(\alpha'') = \frac{\phi(\alpha') - \phi(0)}{\alpha'} = c_1 \phi'(0).$$

因为 $0 < c_1 < c_2$ 且 $\phi'(0) < 0$，α'' 处同时有

$$\phi'(\alpha'') > c_2 \phi'(0), \qquad |\phi'(\alpha'')| < c_2 |\phi'(0)|.$$

ϕ' 连续，这两个严格不等式在 α'' 的一个邻域内保持；邻域取得足够小时留在 $(0, \alpha')$ 中，Armijo 条件也严格成立。 ■

定理保证了存在，算法还要把这样的步长找出来。满足 Wolfe 条件的一个简单办法是二分。维护区间 $[\alpha_{\text{lo}}, \alpha_{\text{hi}}]$，初值为 $[0, \infty)$，用一个试探点 α：Armijo 不满足，就令 $\alpha_{\text{hi}} = \alpha$；Armijo 满足而曲率条件不满足，就令 $\alpha_{\text{lo}} = \alpha$；两者都满足则接受。新试探点取区间中点，上端还是无穷时取 $2\alpha_{\text{lo}}$。

这个过程有限步终止。假如一直不停，且 α_{hi} 始终是无穷，则 $\alpha_{\text{lo}} \to \infty$ 且都满足 Armijo 条件，推出 $\phi \to -\infty$，与下界矛盾。

否则区间缩到一点 α_∞。由端点的 Armijo 状态，$\phi(\alpha_{\text{hi}})$ 在直线上方，$\phi(\alpha_{\text{lo}})$ 在直线下方，两者作差商后取极限，得到 $\phi'(\alpha_\infty) \geq c_1 \phi'(0)$。另一方面 α_{lo} 不满足曲率条件，取极限得到 $\phi'(\alpha_\infty) \leq c_2 \phi'(0)$。于是

$$c_1 \phi'(0) \leq \phi'(\alpha_\infty) \leq c_2 \phi'(0).$$

而 $c_1 < c_2$、$\phi'(0) < 0$ 说明 $c_2 \phi'(0) < c_1 \phi'(0)$，矛盾。

用例子走两次。从 $\alpha = 1$ 开始时，1 和 0.5 都不满足 Armijo 条件，上端缩到 0.5，试探 0.25，两个条件都满足，接受。从 $\alpha = 0.05$ 开始时，Armijo 满足，曲率条件不满足，下端更新为 0.05，上端还是无穷，试探 0.1，它恰

好落在 Wolfe 区间的左端点上，接受。强 Wolfe 条件要用更细致的分段放大与缩小程序，每轮通常只需很少几次试探，具体写法可查阅[2]。

[2] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

Wolfe 条件怎样避免步长过小　下面的定理把“不会太小”写成定量结论，并给出它累积起来的效果。这里只要求当前点和接受点之间满足 Lipschitz 条件。

定理 5.9　Wolfe 步长的下界与累积下降　设步长 α 满足 Wolfe 条件，$\boldsymbol{x}$ 与 $\boldsymbol{x}+\alpha\boldsymbol{d}$ 这一对点满足以 L 为常数的式 (5.2)。则

$$\alpha \geq \frac{(1-c_2)|\langle \boldsymbol{g}, \boldsymbol{d}\rangle|}{L\|\boldsymbol{d}\|_2^2}, \tag{5.26}$$

$$f(\boldsymbol{x}) - f(\boldsymbol{x}+\alpha\boldsymbol{d}) \geq \frac{c_1(1-c_2)}{L}\cos^2\theta\,\|\boldsymbol{g}\|_2^2, \tag{5.27}$$

其中 θ 是 $\boldsymbol{d}$ 与 $-\boldsymbol{g}$ 的夹角。若 f 下有界，且迭代的每一步都满足上述假设，则

$$\sum_{t=0}^{\infty} \cos^2\theta^{(t)}\,\|\boldsymbol{g}^{(t)}\|_2^2 < \infty. \tag{5.28}$$

证明　从曲率条件 (5.23)两端减去 $\langle \boldsymbol{g}, \boldsymbol{d}\rangle$，得到

$$\langle \nabla f(\boldsymbol{x}+\alpha\boldsymbol{d}) - \boldsymbol{g}, \boldsymbol{d}\rangle \geq (c_2-1)\langle \boldsymbol{g}, \boldsymbol{d}\rangle = (1-c_2)|\langle \boldsymbol{g}, \boldsymbol{d}\rangle|.$$

由 Cauchy–Schwarz 不等式和假设，左端不超过 $L\alpha\|\boldsymbol{d}\|_2^2$，于是式 (5.26)成立。

把式 (5.26)代入 Armijo 条件 (5.17)，一步下降量不小于

$$c_1\alpha|\langle \boldsymbol{g}, \boldsymbol{d}\rangle| \geq \frac{c_1(1-c_2)}{L}\cdot\frac{\langle \boldsymbol{g}, \boldsymbol{d}\rangle^2}{\|\boldsymbol{d}\|_2^2},$$

再由 $\cos\theta$ 的定义，即得式 (5.27)。

对 $t=0,\dots,T-1$ 累加，左端不超过 $f(\boldsymbol{x}^{(0)}) - \inf f$，与 T 无关。令 $T\to\infty$，式 (5.28)成立。 ∎

式 (5.28)称为Zoutendijk 条件（Zoutendijk condition）。它把线搜索和方向分开：线搜索保证了这个级数收敛，方向只需不要越来越贴近等高线。若 $\cos\theta^{(t)} \geq \delta > 0$ 一直成立，就有 $\|\boldsymbol{g}^{(t)}\|_2 \to 0$。回到图 5.12的序列：那里 $\cos\theta^{(t)} = 1$，梯度却不趋于零，它违反的正是曲率条件。

下降量 (5.27)和式 (5.16)形式相同，只是常数不同。这说明 Wolfe 条件在不知道 L 的情况下，达到了和按 L 选步长同量级的保证。

拟牛顿曲率更新中的用途 第 8章的方法用相邻两点的梯度差来逼近曲率。设相邻两点的位移和梯度差是

$$\boldsymbol{s} = \alpha \boldsymbol{d}, \qquad \boldsymbol{y} = \nabla f(\boldsymbol{x} + \alpha \boldsymbol{d}) - \boldsymbol{g}.$$

若要让对称正定矩阵 $\boldsymbol{B}$ 满足 $\boldsymbol{B}\boldsymbol{s} = \boldsymbol{y}$，两边与 $\boldsymbol{s}$ 作内积，就得到必要条件

$$\langle \boldsymbol{s}, \boldsymbol{y} \rangle = \langle \boldsymbol{s}, \boldsymbol{B}\boldsymbol{s} \rangle > 0.$$

这个条件对非凸目标不会自动成立，而 Wolfe 条件恰好保证它。由曲率条件，

$$\langle \boldsymbol{s}, \boldsymbol{y} \rangle = \alpha\big(\phi'(\alpha) - \phi'(0)\big) \geq \alpha(1 - c_2)|\phi'(0)| > 0. \tag{5.29}$$

这里只需要 Wolfe 条件，不需要强 Wolfe 条件。

用 $f(x) = 1 - \cos x$、$x = 2$、$d = -1$ 看两个步长，取 $c_1 = 0.1$，$c_2 = 0.9$。此时 $\phi'(0) = -\sin 2 \approx -0.909$。图 5.14中，黄线和绿线对应下面的两个候选：

$$\alpha = 0.4: \quad \phi'(\alpha) \approx -1.000, \quad \langle \boldsymbol{s}, \boldsymbol{y} \rangle \approx -0.036,$$

$$\alpha = 1.3: \quad \phi'(\alpha) \approx -0.644, \quad \langle \boldsymbol{s}, \boldsymbol{y} \rangle \approx 0.345.$$

两者都满足 Armijo 条件。$\alpha = 0.4$ 不满足曲率条件，得到的 $\langle \boldsymbol{s}, \boldsymbol{y} \rangle$ 是负的，不能用来更新正定矩阵；$\alpha = 1.3$ 满足 Wolfe 条件，可以使用。

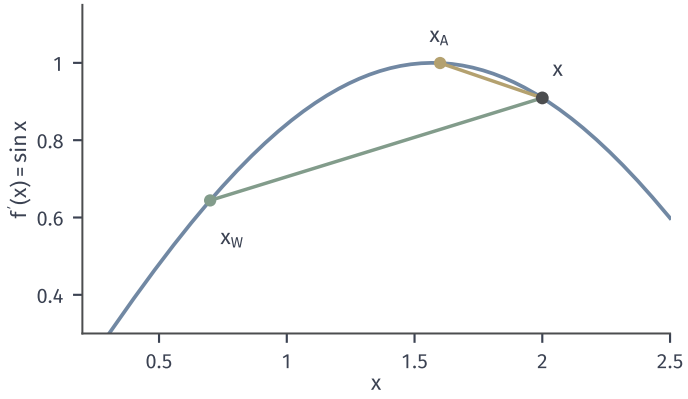


图 5.14 曲率条件与割线斜率。蓝线是 $f(x) = 1 - \cos x$ 的导数 $\sin x$，深灰点是当前点 $x = 2$，沿 $d = -1$ 移动。黄点 $x_{\mathrm{A}} = 1.6$ 只满足 Armijo 条件，割线斜率 y/s 为负。绿点 $x_{\mathrm{W}} = 0.7$ 满足 Wolfe 条件，割线斜率为正。

非线性共轭梯度的下降分析中的用途 强 Wolfe 条件的用处在另一类方法。第 6章的非线性共轭梯度法把新方向取成新的负梯度加上旧方向的倍数。下面记新点的梯度为 $\boldsymbol{g}_+$，系数为 β：

$$\boldsymbol{d}_+ = -\boldsymbol{g}_+ + \beta \boldsymbol{d}.$$

新方向要是下降方向，需要检查它的方向导数：

$$\langle \boldsymbol{g}_+, \boldsymbol{d}_+ \rangle = -\|\boldsymbol{g}_+\|_2^2 + \beta \langle \boldsymbol{g}_+, \boldsymbol{d} \rangle. \tag{5.30}$$

第二项中的 $\langle \boldsymbol{g}_+, \boldsymbol{d} \rangle$ 恰好是上一轮落脚点的方向导数。它若太大，加上 β 的放大可能抵消第一项，新方向就不再下降。Wolfe 条件只限制它不能太负，对正的一侧不设限；强 Wolfe 条件才限制它的绝对值。

图 5.15用具体的向量说明差别。取 $\boldsymbol{g} = (2, 0)$，$\boldsymbol{d} = -\boldsymbol{g}$，系数取一种常见形式：

$$\beta = \frac{\|\boldsymbol{g}_+\|_2^2}{\|\boldsymbol{g}\|_2^2}.$$

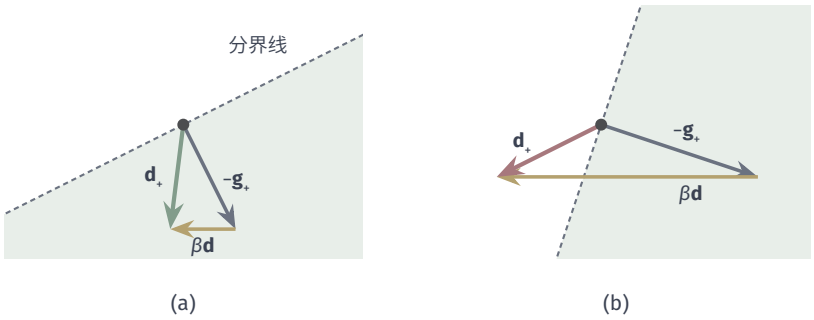


图 5.15　落脚点的方向导数决定新方向是否下降。浅绿区域是 $\boldsymbol{g}_+$ 对应的下降半平面，虚线是分界线。旧方向 $\boldsymbol{d} = (-2, 0)$，灰色箭头是 $-\boldsymbol{g}_+$，黄色箭头是 $\beta\boldsymbol{d}$，两者之和是 $\boldsymbol{d}_+$。(a)$\boldsymbol{g}_+ = (-0.5, 1)$，$\langle \boldsymbol{g}_+, \boldsymbol{d} \rangle = 1$，绿色的 $\boldsymbol{d}_+$ 留在半平面内。(b)$\boldsymbol{g}_+ = (-3, 1)$，$\langle \boldsymbol{g}_+, \boldsymbol{d} \rangle = 6$，超过 $|\langle \boldsymbol{g}, \boldsymbol{d} \rangle| = 4$，红色的 $\boldsymbol{d}_+$ 落到半平面之外。

两种情形的数值分别是

$$\boldsymbol{g}_+ = (-0.5, 1): \quad \beta = 0.3125, \quad \langle \boldsymbol{g}_+, \boldsymbol{d}_+ \rangle = -0.9375,$$
$$\boldsymbol{g}_+ = (-3, 1): \quad \beta = 2.5, \quad \langle \boldsymbol{g}_+, \boldsymbol{d}_+ \rangle = 5.$$

后一种情形的新方向是上升方向。强 Wolfe 条件取 $c_2 < 1$ 就排除了这种比值大于 1 的情况；要在所有轮次都保证下降，还需要对 c_2 的进一步限制和相应的 β 公式，这些在第 6章讨论。常用参数也反映了这种分工：拟牛顿法常取 $c_2 = 0.9$，非线性共轭梯度常取 $c_2 = 0.1$[3]。

[3] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

精确线搜索：只作理论对照　把窗口一直收紧，就得到**精确线搜索**（exact line search）：取 ϕ 的最小点，至少满足

$$\langle \nabla f(\boldsymbol{x} + \alpha \boldsymbol{d}), \boldsymbol{d} \rangle = 0. \tag{5.31}$$

这是 $c_2 \to 0$ 时强 Wolfe 条件的极限。此时式 (5.30)的第二项消失，分析变得干净，所以理论推导常先考虑它。

二次目标上式 (5.11)给出显式解。例 (5.1)用精确步长，从形如 $r(9,\pm 1)$ 的点出发，一步到达 $0.8r(9,\mp 1)$，所以

$$\boldsymbol{x}^{(t)} = 0.8^t\big(9,(-1)^t\big).$$

下一轮的方向是下一轮的负梯度，式 (5.31)说明相邻方向互相垂直，于是路径成直角锯齿，如图 5.16。

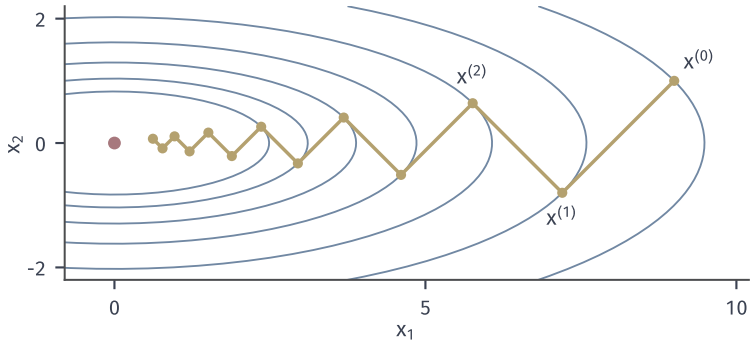


图 5.16 精确线搜索的路径。黄点是例 (5.1)上负梯度方向取精确步长的迭代点，蓝线是经过这些点的等高线。每一段都在终点与等高线相切，相邻两段互相垂直，目标每轮乘以 0.64。

“精确”并不等于最好。这个例子上精确线搜索每轮目标缩小到 0.64 倍，而下一节会看到，回溯用更少的轮数就达到了同样的精度。对一般目标，精确求解一维问题要多次函数或梯度计算，非凸时还要说明找的是哪个局部最小点。因此实际算法使用有限的接受条件，精确线搜索只作为分析时的对照。

三种规则的比较 表 5.3汇总本节的比较。比较的对象都是沿固定下降方向选步长，差别在事先要什么信息、每轮多算什么、换来什么保证。

规则	事先需要	每轮额外计算	保证
固定步长	L 的上界，方向的尺度	无	式 (5.13)、(5.16)
回溯（Armijo）	下降方向，初始试探步长	n 次函数值	式 (5.21)
Wolfe	ϕ 有下界	函数值和方向导数	式 (5.27)，$\langle \boldsymbol{s},\boldsymbol{y}\rangle > 0$
强 Wolfe	同上	同上，试探常更多	另限制落脚点方向导数的绝对值
精确线搜索	ϕ 的最小点可求	一维优化	落脚点方向导数为零

表 5.3 选择步长的规则。各行的保证都针对固定的下降方向，方向的质量由夹角 θ 单独体现。

5.1 光滑性
5.2 步长的选择
5.3 求解误差与计算成本
5.4 本章小结

5.3 求解误差与计算成本

上一节比较的是单步。一个算法要迭代许多轮，两个算法之间的比较还要回答更多问题。这就需要回答：两种方法求解同一个问题，怎样比较才算数？第 1章规定了怎样衡量一个近似解，本节把它接到迭代过程上，再加上计算量的统计。

结论会随口径翻转 在例 (5.1)上，从 $\boldsymbol{x}^{(0)}=(9,1)$ 出发，用五种步长规则运行负梯度方法，直到目标差不超过 10^{-6}。表 5.4列出外层轮数和各种读取次数。这里算总次数时把一次函数值、一次梯度、一次矩阵向量积各记为一个单位，因为对二次目标它们都要做一次矩阵向量积。

步长规则	轮数 T	函数值	梯度	矩阵向量积	总次数
固定 $\alpha=1/L$	75	0	76	0	76
固定 $\alpha=0.2$	40	0	41	0	41
精确线搜索	40	0	41	40	81
回溯，$\alpha_0=1$	23	71	24	0	95
回溯，初值放大	31	65	32	0	97

表 5.4 例 (5.1)上负梯度方法达到目标差不超过 10^{-6} 的计算量。固定步长 $0.2=2/(L+\mu)$ 要同时知道 L 和 μ；梯度数包含初始点。回溯的函数值数包含初始点和所有被拒绝的试探。

按轮数看，回溯最少，比第二名少了将近一半。按总次数看，排序几乎反过来：回溯不如不做任何试探的固定步长，而精确线搜索也花掉了比固定步长 0.2 多一倍的计算。图 5.17中两张图的曲线次序不同，差别只在横轴。

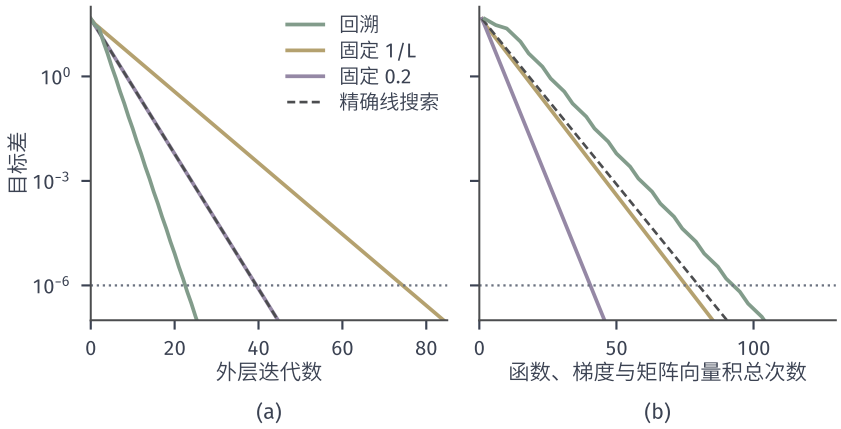


图 5.17 同一组运行的两种横轴，目标见例 (5.1)，纵轴是目标差，点线是 10^{-6}。(a) 横轴是外层迭代数，绿色的回溯最快。(b) 横轴是函数值、梯度与矩阵向量积的总次数，紫色的固定步长 0.2 最快。回溯曲线在 (b) 中被试探次数拉长。

这个例子不说明哪种规则更好。若函数值远比梯度便宜，或者 L 和 μ 未知，结论都要改变。它说明的是：不交代口径的比较没有意义。比较之前要固定三件事：用什么量衡量误差，算法交出哪个点，计算量怎样累计。

误差标准 第 1章的三种指标在这里要按问题类型选择。凸目标上驻点就是全局最优解，目标差 $e_f = f(\boldsymbol{x}) - f^\star$ 有明确的含义，比较时通常用它，保证也通常写成目标差的形式。

一般非凸目标的 $f^\star$ 既算不出来，算法也无法保证接近它。这时能够断言的只有驻点残差 $e_g = \|\nabla f(\boldsymbol{x})\|_2$：它只回答一阶条件差多少，不说明是局部还是全局的最小点，这在第 10章还要细分。

两种标准之间的换算，依据是第 1章三种误差的换算和本章的式 (5.8)。由目标差推梯度只要 L：

$$e_g \le \sqrt{2L\, e_f}.$$

由梯度推目标差还要曲率下界 μ：

$$e_f \le \frac{e_g^2}{2\mu}.$$

例 (5.1)中 $L = 9$，$\mu = 1$。目标差 10^{-6} 只保证梯度不超过 $\sqrt{18}\times 10^{-3} \approx 4.2\times 10^{-3}$；梯度 10^{-3} 保证目标差不超过 5×10^{-7}。所以两种标准的“同样精度”并不相同，比较时不能混用。

一步下降怎样累积成驻点保证 前面三种步长规则的下降保证都能写成同一个形式：一步的下降量不少于 $c\|\boldsymbol{g}^{(t)}\|_2^2$，$c$ 是正常数。把这种形式累加起来，就得到不依赖凸性的驻点保证。

引理 5.10　累加下降　设 f 下有界，$f_{\inf} = \inf f$，常数 $c > 0$，迭代满足

$$f(\boldsymbol{x}^{(t)}) - f(\boldsymbol{x}^{(t+1)}) \geq c\|\boldsymbol{g}^{(t)}\|_2^2, \qquad t = 0, \dots, T-1. \tag{5.32}$$

则

$$\min_{0 \leq t < T} \|\boldsymbol{g}^{(t)}\|_2^2 \leq \frac{f(\boldsymbol{x}^{(0)}) - f_{\inf}}{cT}. \tag{5.33}$$

证明　对 $t = 0, \dots, T-1$ 累加式 (5.32)，左端相消，得到

$$f(\boldsymbol{x}^{(0)}) - f(\boldsymbol{x}^{(T)}) \geq c \sum_{t=0}^{T-1} \|\boldsymbol{g}^{(t)}\|_2^2 \geq cT \min_{0 \leq t < T} \|\boldsymbol{g}^{(t)}\|_2^2.$$

左端不超过 $f(\boldsymbol{x}^{(0)}) - f_{\inf}$，移项即得。 ■

由式 (5.33)，要使 $\min_t \|\boldsymbol{g}^{(t)}\|_2 \leq \varepsilon$，轮数只要达到

$$T \geq \frac{f(\boldsymbol{x}^{(0)}) - f_{\inf}}{c\,\varepsilon^2}. \tag{5.34}$$

下一章将用这种累加结果处理一般非凸情形。三种规则对应的常数 c 如下，方向都取负梯度，Wolfe 的情形允许夹角满足 $\cos\theta^{(t)} \geq \delta > 0$ 的一般方向，此时下降量与 $\|\boldsymbol{g}^{(t)}\|_2^2$ 的比例同样有正下界：

$$\begin{aligned} \text{固定步长 } \alpha = \tfrac{1}{L}: \quad & c = \frac{1}{2L}, \\ \text{回溯}: \quad & c = \min\Big\{c_1\alpha_0,\ \frac{2\rho c_1(1-c_1)}{L}\Big\}, \\ \text{Wolfe}: \quad & c = \frac{c_1(1-c_2)\delta^2}{L}. \end{aligned}$$

代入例 (5.1) 的数值，看看这种保证和实际运行的距离。$f(\boldsymbol{x}^{(0)}) - f_{\inf} = 45$，$L = 9$，取 $\varepsilon = 10^{-3}$。固定步长 $1/L$ 的 $c = 1/18$，式 (5.34) 要求 $T \geq 8.1 \times 10^8$，而实际只用了 78 轮。

差距这样大是因为式 (5.33) 对任意 L 光滑的目标成立，包括最坏的非凸函数，它没有用到这个例子的二次结构。因此要区分两种“轮数”：理论界是对一类问题的最坏保证，实测值是在一个问题上的表现。两者都有用，但不能相互替代。

返回哪个迭代点 式 (5.33)左端是历史上最小的梯度，所以保证的是某一轮的点，不一定是最后一轮。这个区别不是形式上的。取 $f(x)=1-\cos x$，固定步长 $\alpha=1/L=1$，从 $x^{(0)}=3$ 出发。前四轮的迭代值如下：

$$\begin{aligned} x &: \ 3,\ 2.859,\ 2.580,\ 2.047,\ 1.159, \\ f &: \ 1.990,\ 1.960,\ 1.846,\ 1.459,\ 0.600, \\ |f'| &: \ 0.141,\ 0.279,\ 0.533,\ 0.889,\ 0.916. \end{aligned}$$

目标在下降，梯度却在上升，如图 5.18。起点靠近山顶 $x=\pi$，那里梯度很小；离开山顶的过程中坡度越来越陡。由此可见，下降引理只控制目标的单调性，不控制梯度的单调性。

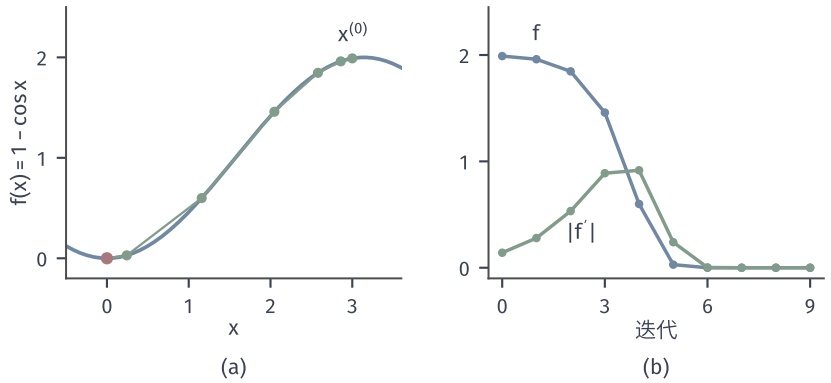


图 5.18 目标单调下降时梯度可以先升后降。$f(x)=1-\cos x$，$\alpha=1$，$x^{(0)}=3$。(a) 曲线上的迭代点（绿色）。(b) 目标值（蓝）单调下降，导数绝对值（绿）在前四轮上升，到第 5 轮后才迅速下降。

这个例子还有另一面：若容差取 $\varepsilon=0.2$，初始点 $x^{(0)}=3$ 本身就能通过检验，而它靠近的是极大点。所以驻点残差小只是一阶条件的说明，它不区分山顶与谷底。

报告结果时，常见的返回规则有三种。一是最后一轮 $\boldsymbol{x}^{(T)}$，凸目标上的多数保证针对它，不需要记录历史。二是历史最佳，即目标值或梯度范数最小的那一轮，式 (5.33)对应这种规则，需要额外记录。三是停止点，第一次满足 $\|\boldsymbol{g}^{(t)}\|_2\le\varepsilon$ 的那一轮，停止时它就是历史上第一个合格的点。

下一章有些方法的目标值不单调，最后一轮不一定是最好的一轮，这时必须说明按哪条规则返回。

停止精度 实际运行时 $f^\star$ 未知，停止规则只能用可计算的量。梯度范数是首选，第 1章的相对标准，即把容差乘以 $\max\{1,\|\boldsymbol{g}^{(0)}\|_2\}$，能够避免目标整体缩放带来的问题。步长或目标变化量太小的检验只能作辅助：回溯在

一轮中接受了很小的步长时，位移也很小，但这只反映这一轮的步长，并不说明点已接近驻点。

容差还要与计算机的能力相称。在双精度浮点数中，$1+\delta$ 对 δ 小于约 1.1×10^{-16} 的数等于 1。考虑 $f(x)=1+\frac{1}{2}x^2$，$x=10^{-9}$ 时，真实值 $1+5\times10^{-19}$ 与 1 无法区分。

因此在最优值附近，比较函数值只能把点确定到约 $\sqrt{\text{机器精度}}\approx10^{-8}$ 的范围，Armijo 检验也就失去了分辨力。梯度 $f'(x)=x$ 却还能算准。这说明可达到的精度取决于用什么量作判断，容差设得比判断量的计算误差还小是没有意义的。

总计算量　选定误差标准和返回规则后，记 $T(\varepsilon)$ 为达到精度 ε 所需的外层轮数。总计算量要把每一轮实际做过的所有运算加起来。设一次函数值、梯度、矩阵向量积的代价分别是 $c_f, c_g, c_{\mathrm{mv}}$，第 t 轮有 $n^{(t)}$ 次函数计算、$k^{(t)}$ 次内层矩阵向量积、线性代数运算量 $c_{\mathrm{la}}^{(t)}$，于是

$$W(\varepsilon)=\sum_{t=0}^{T(\varepsilon)-1}\left(n^{(t)}c_f+c_g+k^{(t)}c_{\mathrm{mv}}+c_{\mathrm{la}}^{(t)}\right). \tag{5.35}$$

式中 $n^{(t)}$ 包含被拒绝的试探；$k^{(t)}$ 是用迭代法解内层线性方程时的步数。图 5.19显示了每一轮的三部分怎样累加成 $W(\varepsilon)$。

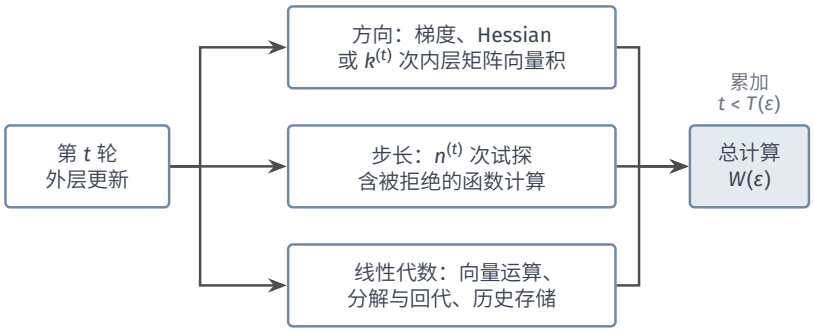


图 5.19　总计算量的组成。每一轮外层更新包含方向计算、步长试探和线性代数三部分，对达到精度所需的全部轮次累加，得到 $W(\varepsilon)$。迭代轮数只决定累加的项数，每项的大小要另外统计。

单次更新的代价　不同方法的每轮代价差别很大。表 5.5按 n 维稠密问题列出下一章起要用到的几类操作。其中第三行的方向要解线性方程 $\boldsymbol{H}\boldsymbol{d}=-\boldsymbol{g}$：可以分解矩阵直接解，也可以用迭代法只做矩阵向量积、解到一定精度为止，后者就是内层求解。

一轮更新的操作	运算量	存储
梯度与向量更新	$c_g + O(n)$	$O(n)$
回溯线搜索	再加 $n^{(t)} c_f$	$O(n)$
分解 Hessian 解方程	$c_H + \frac{1}{3}n^3 + O(n^2)$	$O(n^2)$
内层迭代解方程	$k^{(t)} c_{\mathrm{mv}} + O(k^{(t)} n)$	$O(n)$

表 5.5　一轮更新中常见操作的代价，c_H 是形成一次 Hessian 的代价，分解按 Cholesky 计。单轮代价低的方法不一定总代价低。

单轮代价和总代价是两个不同的量。用线性方程的三种解法作对照最清楚，$\boldsymbol{H}\boldsymbol{x} = \boldsymbol{b}$ 等价于最小化 $\frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{H}\boldsymbol{x} - \boldsymbol{b}^{\top}\boldsymbol{x}$，设 $\boldsymbol{H}$ 稠密、$\kappa = L/\mu$，要把目标差缩小到初值的 ε 倍。下面三个数都是最坏情形的估计。

梯度下降取 $\alpha = 1/L$ 时，每个特征方向的乘数绝对值不超过 $1 - 1/\kappa$，目标差每轮至少乘 $(1 - 1/\kappa)^2$，所以轮数约是

$$T_{\mathrm{GD}} \approx \frac{\kappa}{2} \ln \frac{1}{\varepsilon}.$$

共轭梯度法的能量范数误差不超过 $2q^{T}\|\boldsymbol{e}^{(0)}\|_{\boldsymbol{H}}$，其中 $q = (\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$，这一结论的证明可参考卷二第 15 章“Krylov 子空间法”。由 $\ln(1/q) \approx 2/\sqrt{\kappa}$，轮数约是

$$T_{\mathrm{CG}} \approx \frac{\sqrt{\kappa}}{4} \ln \frac{4}{\varepsilon}.$$

两者每轮都是一次矩阵向量积，约 $2n^2$ 次运算。Cholesky 分解约 $n^3/3$ 次运算，外加回代 $2n^2$ 次。取 $\kappa = 100$，$\varepsilon = 10^{-6}$，代入得到

$$T_{\mathrm{GD}} \approx 691, \qquad T_{\mathrm{CG}} \approx 39.$$

单轮代价是 $n^3/3$ 与 $2n^2$ 之比，单看一轮，迭代法便宜得多。把轮数算上，令 $2n^2 T = n^3/3$，交叉点在 $n = 6T$：

$$n_{\mathrm{GD}} \approx 4146, \qquad n_{\mathrm{CG}} \approx 234.$$

图 5.20画出这三条总运算量曲线。维数低于交叉点时，一次分解比许多轮便宜的迭代总和更省。稀疏矩阵的矩阵向量积只需与非零元数成比例的运算，分解却可能产生填充，这时交叉点又会移动，比较要重新做。

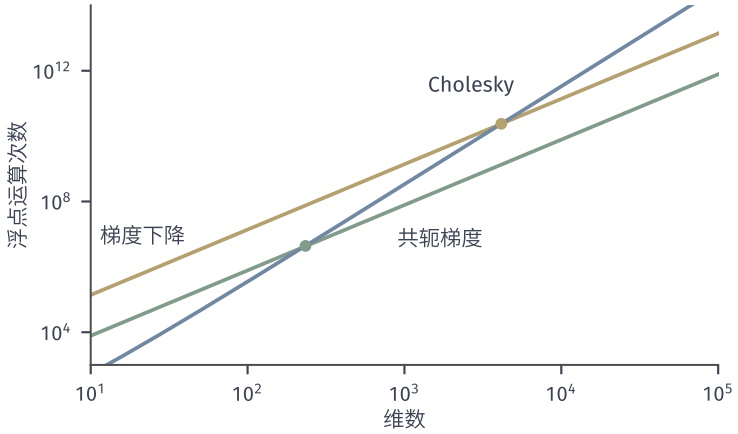


图 5.20 稠密对称正定方程的总运算量估计，$\kappa = 100$，$\varepsilon = 10^{-6}$。黄线为梯度下降（691 轮），绿线为共轭梯度（39 轮），每轮 $2n^2$ 次运算；蓝线为 Cholesky 分解加回代。两个点是迭代法与分解的交叉位置，$n \approx 4146$ 和 $n \approx 234$。

内层求解 外层方法里嵌套内层迭代时，式 (5.35)的 $k^{(t)}$ 不能忽略。作为教学算例，假设一种用 Hessian 的方法外层只要 6 轮，每轮用 20 次矩阵向量积近似解方程，矩阵向量积与梯度代价相同；另一种只用梯度的方法要 60 轮。按外层轮数比较前者少 10 倍，按读取次数比较则是

$$6 \times (1 + 20) = 126, \qquad 60 \times 1 = 60.$$

结论反了过来。内层容差也属于口径的一部分：内层解得越精确，外层轮数可能越少，每轮却越贵，第 7章会讨论两者的权衡。

比较时要报告的内容 把上面的要求列在一起，就是本卷后面比较算法时使用的口径，见表 5.6。按表中各项报告，读者才能判断两组数字是否可比。

项目	需要交代的内容
问题与起点	目标的结构、维数、初始点
误差标准	目标差或驻点残差，绝对或相对容差
返回规则	最后一轮、历史最佳或停止点
外层统计	达到容差的轮数 $T(\varepsilon)$
读取统计	函数值、梯度、Hessian、矩阵向量积的次数
被拒绝的试探	计入函数计算次数
线性代数	分解、回代、内层迭代的运算量和存储
结论类型	最坏情形的理论界，或特定问题上的实测值

表 5.6 比较优化算法时的报告项目。同一项目口径不同的两组结果不能直接比较。

5.4 本章小结

5.1 光滑性
5.2 步长的选择
5.3 求解误差与计算成本
5.4 本章小结

本章开头问：只看得清脚下时，一步可以走多远，走完又怎样评价？回答分成三层。

光滑性给出了依据。L 是梯度变化的限速，由它得到下降引理 (5.4)：一个与目标相切的二次函数从上方盖住目标。这个上界只在 L 成立的区域内有效，与凸性互不蕴含。二阶可微时最小的 L 就是 Hessian 谱范数的上确界。

步长规则负责检验局部预测。固定步长靠事先知道的 L，负梯度方向上要求 $\alpha < 2/L$，一般方向要重新核对长度和方向导数。回溯用真实函数值检验 Armijo 条件，只要方向下降就有限步终止，代价是被拒绝的试探。Wolfe 条件再检验落脚点的方向导数，挡住太短的步长，并保证拟牛顿更新所需的 $\langle \boldsymbol{s}, \boldsymbol{y} \rangle > 0$；强 Wolfe 条件进一步限制方向导数的绝对值，供非线性共轭梯度的下降分析使用。精确线搜索只作理论对照。

比较方法要同时固定三件事：误差标准、返回的迭代点、计算量的口径。在例 (5.1)上，同一组运行按轮数和按读取次数排出的顺序几乎相反。凸目标通常用目标差，一般非凸目标只能用驻点残差，后者只说明一阶条件满足到什么程度。式 (5.35)把被拒绝的试探和内层求解都算进总计算量。

这些规则都假设了下降方向已经给定。后面几章的问题是方向从哪里来：第 6章只用梯度和历史位移，第 7章用 Hessian，第 8章用梯度差拼出曲率，第 9章把方向和步长放在一起决定，第 10章处理非凸目标中的鞍点。各章的收敛保证需要哪些附加条件，都在本章的标准下分别说明。

6.1 梯度下降
6.2 动量与加速
6.3 非线性共轭梯度法
6.4 收敛与计算成本
6.5 本章小结

第 6 章

一阶方法

设想站在一片山谷里，四周被雾遮住。每走到一处，只能用脚试出当地的坡度，也就是目标的函数值和梯度，看不到整个地形，也量不出地面的弯曲。这正是大规模优化最常见的处境：变量很多，Hessian 算不起也存不下，一次梯度却是可以负担的。

本章全程使用同一个目标来比较各种走法：

$$f(\boldsymbol{x}) = \frac{1}{2}\bigl(x_1^2 + 9x_2^2\bigr), \qquad \boldsymbol{x}^{(0)} = (9, 1). \tag{6.1}$$

它的等高线是横向拉长的椭圆，最优解是原点。Hessian 是 $\boldsymbol{H} = \operatorname{diag}(1, 9)$，所以 $\mu = 1$，$L = 9$，$\kappa = 9$。沿 x_1 方向地面平缓，沿 x_2 方向地面陡峭，这种“一个方向平、一个方向陡”的山谷称为病态的目标。

最朴素的走法是每步顺着最陡的方向下山。第 6.1节会看到，它在这个山谷里左右折返，大部分力气消耗在陡峭方向上。那么，能不能利用走过的路？第 6.2节把上一步的位移加进当前更新，并比较梯度取在当前点和取在试探点这两种做法。第 6.3节换一种用历史的方式：保留上一轮的搜索方向，与新梯度组合，再用线搜索决定走多远。

几种方法花费的计算不同，得到的保证也不同。有的保证只对二次目标成立，有的要求凸，有的只能说梯度变小。第 6.4节把它们放在同一把尺子下比较，并说明为什么迭代次数少不等于总计算少。

6.1 梯度下降

只知道当前点的函数值和梯度，下一步应该朝哪里走、走多远？本节回答这个问题，并分三种情形说明这样走能得到什么：一般非凸、凸、强凸。三种情形的结论强弱不同，度量误差的尺子也不同。

主要思想　先看方向。在 $\boldsymbol{x}$ 附近，目标由一阶 Taylor 展开近似：

$$f(\boldsymbol{x} + \boldsymbol{d}) \approx f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})^{\top} \boldsymbol{d}.$$

在固定长度的 $\boldsymbol{d}$ 中，要让 $\nabla f(\boldsymbol{x})^{\top}\boldsymbol{d}$ 最小。由 Cauchy–Schwarz 不等式，

$$\nabla f(\boldsymbol{x})^{\top}\boldsymbol{d} \geq -\|\nabla f(\boldsymbol{x})\|_2\|\boldsymbol{d}\|_2,$$

等号当且仅当 $\boldsymbol{d}$ 与 $-\nabla f(\boldsymbol{x})$ 同向时成立。所以局部最陡的下降方向是负梯度方向。

线性模型只给方向，不给距离：沿负梯度走得越远，线性模型的值越低，没有尽头。真实的地面会弯曲，线性预测走远了就不可信。需要一个量来说明“能信多远”。

这个量就是第 5章的光滑常数 L，它要求梯度满足 Lipschitz 条件：

$$\|\nabla f(\boldsymbol{x}) - \nabla f(\boldsymbol{y})\|_2 \leq L\|\boldsymbol{x} - \boldsymbol{y}\|_2.$$

在这个条件下，下降引理给出处处成立的二次上界：

$$f(\boldsymbol{y}) \leq f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})^{\top}(\boldsymbol{y} - \boldsymbol{x}) + \frac{L}{2}\|\boldsymbol{y} - \boldsymbol{x}\|_2^2. \tag{6.2}$$

二阶可微时，$\nabla^2 f \preceq L\boldsymbol{I}$ 且 $\nabla^2 f \succeq -L\boldsymbol{I}$ 就保证了这一点。可以把右端想成扣在地面上的一只碗：它在 $\boldsymbol{x}$ 处贴住地面，其余地方都不低于地面。

既然地面不高于这只碗，就走到碗底。对 $\boldsymbol{y}$ 求右端的最小点，令导数为零，得到 $\boldsymbol{y} = \boldsymbol{x} - \nabla f(\boldsymbol{x})/L$。图 6.1画的是一元的情形：绿色的碗底对应的横坐标就是新点，碗底的高度保证了至少下降多少。

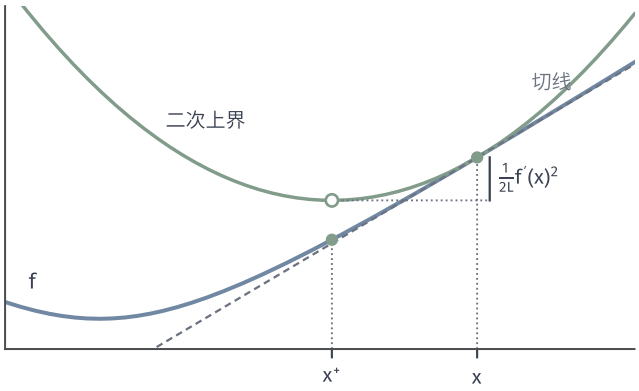


图 6.1　二次上界决定一步走多远。蓝色曲线是 $f(x) = \sqrt{1 + x^2}$，它的二阶导数不超过 1，取 $L = 1$。虚线是 $x = 2.4$ 处的切线，绿色抛物线是式 (6.2)的上界。空心点是上界的最低点，其横坐标 x^{+} 就是新点，实心点是真实的函数值，它不高于空心点。竖线段是保证的下降量。

把步长放宽为任意的 $\alpha > 0$，就得到**梯度下降法**（gradient descent method）：

$$\boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} - \alpha^{(t)}\boldsymbol{g}^{(t)}, \qquad \boldsymbol{g}^{(t)} = \nabla f(\boldsymbol{x}^{(t)}). \tag{6.3}$$

把 $\boldsymbol{y} = \boldsymbol{x}^{(t+1)}$ 代入式 (6.2)，一阶项是 $-\alpha\|\boldsymbol{g}^{(t)}\|_2^2$，二次项是 $\frac{L}{2}\alpha^2\|\boldsymbol{g}^{(t)}\|_2^2$，合起来得到单步下降估计：

$$f(\boldsymbol{x}^{(t+1)}) \le f(\boldsymbol{x}^{(t)}) - \alpha\Big(1 - \frac{L\alpha}{2}\Big)\|\boldsymbol{g}^{(t)}\|_2^2. \tag{6.4}$$

只要 $0 < \alpha < 2/L$，括号就是正的，函数值严格下降。关于 α 求最大的下降量，得到 $\alpha = 1/L$，此时每步至少下降 $\|\boldsymbol{g}^{(t)}\|_2^2/(2L)$。

步长的来源有三种，都沿用第 5章的规则。已知 L 时取固定步长；不知道 L 时用回溯，从一个试探值开始不断缩短，直到满足 Armijo 条件

$$f(\boldsymbol{x} + \alpha\boldsymbol{d}) \le f(\boldsymbol{x}) + c_1\alpha\nabla f(\boldsymbol{x})^{\top}\boldsymbol{d}, \qquad 0 < c_1 < 1; \tag{6.5}$$

二次目标上还可以精确求沿线最小点。负梯度方向的精确步长是

$$\alpha = \frac{\boldsymbol{g}^{\top}\boldsymbol{g}}{\boldsymbol{g}^{\top}\boldsymbol{H}\boldsymbol{g}},$$

这时的方法称为最速下降法（steepest descent）。

变量

- $\boldsymbol{x}^{(t)} \in \mathbb{R}^n$：当前点，在原处更新。
- $\boldsymbol{g}^{(t)} \in \mathbb{R}^n$：当前点的梯度，每轮读取一次。
- $\alpha > 0$：步长，这里固定；用线搜索时每轮重新确定。
- $\varepsilon > 0$，T：梯度大小的容差与最大步数。

初始化　选定起点 $\boldsymbol{x}^{(0)}$、步长、容差，令 $t = 0$。例中用式 (6.1)的起点，并取 $\alpha = 1/5$（下文说明这个值从哪里来），容差 $\varepsilon = 10^{-3}$。初始值是

$$\boldsymbol{x}^{(0)} = (9, 1), \qquad f(\boldsymbol{x}^{(0)}) = 45.$$

每轮更新　在第 t 轮：

1. **读取梯度**。计算 $\boldsymbol{g}^{(t)} = \nabla f(\boldsymbol{x}^{(t)})$。例中 $\nabla f(\boldsymbol{x}) = (x_1, 9x_2)$，第一轮

$$\boldsymbol{g}^{(0)} = (9, 9).$$

2. **检查停止**。若 $\|\boldsymbol{g}^{(t)}\|_2 \le \varepsilon$ 或 $t = T$，输出 $\boldsymbol{x}^{(t)}$ 并结束。例中第一轮 $\|\boldsymbol{g}^{(0)}\|_2 = 9\sqrt{2} \approx 12.73$，继续。
3. **更新**。按式 (6.3)计算新点，令 $t \leftarrow t + 1$。例中第一轮

$$\boldsymbol{x}^{(1)} = (9, 1) - \tfrac{1}{5}(9, 9) = (7.2, -0.8), \qquad f(\boldsymbol{x}^{(1)}) = 28.8.$$

例中第二轮 $\boldsymbol{g}^{(1)} = (7.2, -7.2)$，于是

$$\boldsymbol{x}^{(2)} = (7.2, -0.8) - \tfrac{1}{5}(7.2, -7.2) = (5.76, 0.64),$$

目标值 $f(\boldsymbol{x}^{(2)}) = 18.432$。

例中第三轮 $\boldsymbol{g}^{(2)} = (5.76, 5.76)$，于是

$$\boldsymbol{x}^{(3)} = (5.76, 0.64) - \tfrac{1}{5}(5.76, 5.76) = (4.608, -0.512),$$

目标值 $f(\boldsymbol{x}^{(3)}) = 11.79648$。

规律已经显出来了：两个坐标分别乘以 $1-\alpha\lambda$，第一个因子是 $1-\tfrac{1}{5} = 0.8$，第二个因子是 $1 - \tfrac{9}{5} = -0.8$。因此

$$\boldsymbol{x}^{(t)} = 0.8^t\big(9, (-1)^t\big), \qquad f(\boldsymbol{x}^{(t)}) = 45 \cdot 0.64^t.$$

梯度大小是 $\|\boldsymbol{g}^{(t)}\|_2 = 0.8^t \cdot 9\sqrt{2}$，它不超过 10^{-3} 要求 $t \geq 43$。最终得到

$$\boldsymbol{x}^{(43)} \approx (6.13 \times 10^{-4},\ -6.81 \times 10^{-5}).$$

这个起点是特意选的：沿 $\boldsymbol{d} = -\boldsymbol{g}$ 的精确步长恰好处处等于 $1/5$，所以这串点也是最速下降的结果。

步长与收缩因子 为什么取 $1/5$，而不是上界推出的 $1/L = 1/9$？这要看二次目标上一步到底做了什么。设

$$f(\boldsymbol{x}) = \frac{1}{2}(\boldsymbol{x} - \boldsymbol{x}^\star)^{\top}\boldsymbol{H}(\boldsymbol{x} - \boldsymbol{x}^\star) + f^\star,$$

其中 $\boldsymbol{H}$ 对称正定，特征值都落在 $[\mu, L]$ 内。记 $\boldsymbol{e}^{(t)} = \boldsymbol{x}^{(t)} - \boldsymbol{x}^\star$，由 $\boldsymbol{g}^{(t)} = \boldsymbol{H}\boldsymbol{e}^{(t)}$ 得

$$\boldsymbol{e}^{(t+1)} = (\boldsymbol{I} - \alpha\boldsymbol{H})\boldsymbol{e}^{(t)}.$$

用 $\boldsymbol{H}$ 的标准正交特征向量作坐标，矩阵变成对角形，每个特征方向各自演化。特征值为 λ 的分量每步乘以同一个数：

$$e_\lambda^{(t+1)} = (1 - \alpha\lambda)\, e_\lambda^{(t)}. \tag{6.6}$$

特征分解的做法可参考卷二第 6 章“谱分解”。

步长是所有方向共用的一个数，而不同方向希望的步长不同：λ 方向最想要 $\alpha = 1/\lambda$，一步到位。图 6.2把例中两个方向的因子画在一起。陡峭方向的折线下降得快，在 $\alpha = 1/9$ 处触底，随后反弹；平坦方向的线缓慢下降。整体的进度取决于两条线中较高的那条。

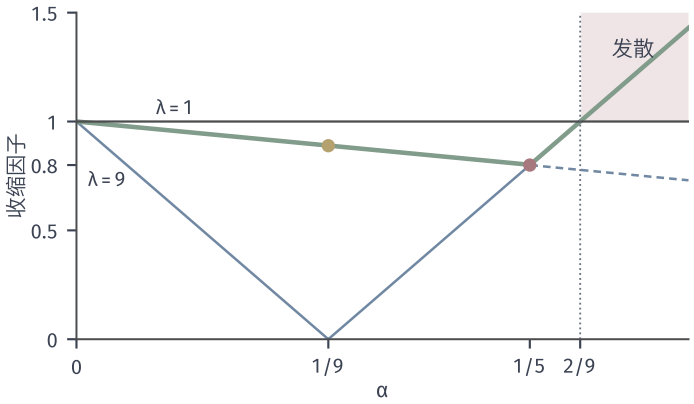


图 6.2　贯穿例上两个特征方向的收缩因子 $|1-\alpha\lambda|$。蓝色实线对应陡峭方向 $\lambda=9$，蓝色虚线对应平坦方向 $\lambda=1$，绿色粗线是两者的较大值。黄点是 $\alpha=1/L=1/9$，红点是使较大值最小的 $\alpha=2/(L+\mu)=1/5$，此时因子等于 0.8。红底区域 $\alpha>2/9$ 中因子超过 1，迭代发散。

要让最慢的方向尽量快，就让两条线相交。这件事可以写成一条定理。

定理 6.1　二次目标上的最佳固定步长　设 $\boldsymbol{H}$ 对称正定，特征值落在 $[\mu, L]$ 内，且 μ 和 L 都是特征值。固定步长的梯度下降收敛到 $\boldsymbol{x}^\star$（对任意起点）当且仅当 $0<\alpha<2/L$。取 $\alpha=2/(L+\mu)$ 时，最大收缩因子最小，并且

$$\|\boldsymbol{x}^{(t)}-\boldsymbol{x}^\star\|_2 \le \left(\frac{\kappa-1}{\kappa+1}\right)^t \|\boldsymbol{x}^{(0)}-\boldsymbol{x}^\star\|_2. \tag{6.7}$$

证明　由式 (6.6)，第 t 步的 λ 分量等于 $(1-\alpha\lambda)^t$ 乘以初值。任意起点都收敛，当且仅当对每个特征值都有 $|1-\alpha\lambda|<1$，即 $0<\alpha\lambda<2$。这在 $\lambda=L$ 时最严格，所以条件是 $0<\alpha<2/L$。

函数 $|1-\alpha\lambda|$ 关于 λ 是凸的，在 $[\mu,L]$ 上的最大值在端点取得，所以最大因子是

$$\rho(\alpha)=\max\{|1-\alpha\mu|,\,|1-\alpha L|\}.$$

随着 α 增大，$1-\alpha\mu$ 减小，$\alpha L-1$ 增大。两者相等时最大值最小，这时 $1-\alpha\mu=\alpha L-1$，解得

$$\alpha=\frac{2}{L+\mu},\qquad \rho=1-\frac{2\mu}{L+\mu}=\frac{\kappa-1}{\kappa+1}.$$

最后，标准正交变换保持欧氏长度，各分量的平方和至多缩小 ρ^2 倍，即得结论。 ■

例中 $\kappa = 9$，$\rho = 8/10 = 0.8$，正是上面算出的因子。起点 $(9, 1)$ 使两个方向同时达到这一因子，所以界 (6.7)在这个例子上取等号。

图 6.3把步长的影响画在等高线上。$\alpha = 1/9$ 时第一步就消掉了 x_2，随后沿谷底以因子 $8/9$ 慢慢前进，路径光滑但慢；$\alpha = 1/5$ 时路径左右折返，前进因子却是 0.8；$\alpha = 0.23$ 超过了 $2/9$，x_2 每步乘以 -1.07，折返幅度越来越大。

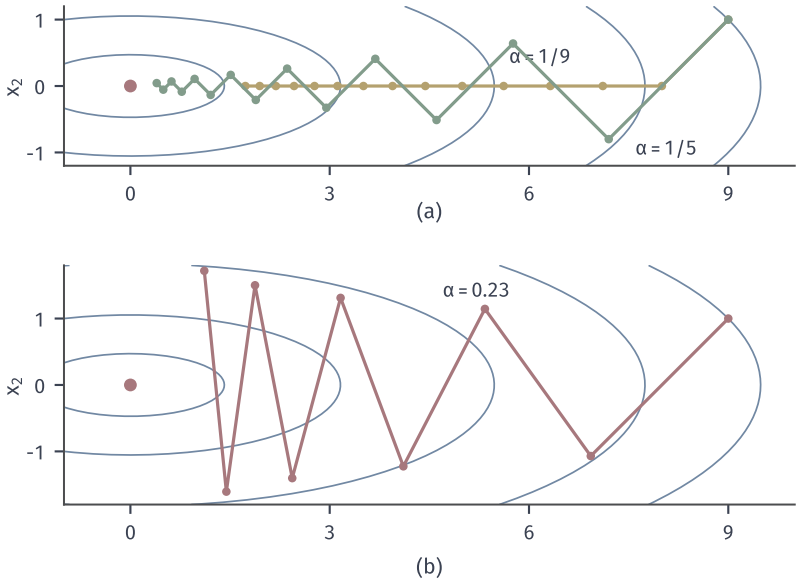


图 6.3　贯穿例上不同固定步长的路径，蓝色椭圆是等高线，红点是最优解。(a) 黄色路径 $\alpha = 1/9$，绿色路径 $\alpha = 1/5$，各走 14 步。(b) 红色路径 $\alpha = 0.23 > 2/L$，走 8 步，x_1 在收缩，x_2 的振幅却在放大。

于是 $\alpha = 1/L$ 与 $\alpha = 2/(L+\mu)$ 回答的是两个不同的问题。前者由上界推出，只用 L，保证函数值每步下降，下面的定理都以它为基础；后者要同时知道 μ 和 L，它在二次目标上收缩最快，函数值也下降，但路径来回摆动。

一般非凸情形：梯度残差　下面离开二次目标。先看最弱的假设：f 可以非凸，只要求梯度 Lipschitz，并且有下界。这时目标差和解距离都无从谈起，因为可能有许多局部的谷底，能评价的只有梯度的大小。

定理 6.2　非凸情形的梯度下降　设 f 的梯度 L-Lipschitz 连续，$f_{\inf} = \inf f > -\infty$。取固定步长 $\alpha = 1/L$，则对任意 $T \ge 1$，

$$\min_{0 \le t < T} \|\boldsymbol{g}^{(t)}\|_2^2 \le \frac{2L\big(f(\boldsymbol{x}^{(0)}) - f_{\inf}\big)}{T}, \tag{6.8}$$

并且 $\|\boldsymbol{g}^{(t)}\|_2 \to 0$，$\{\boldsymbol{x}^{(t)}\}$ 的每个极限点都是驻点。

证明　由式 (6.4)，取 $\alpha = 1/L$ 时每步满足

$$\frac{1}{2L}\|\boldsymbol{g}^{(t)}\|_2^2 \le f(\boldsymbol{x}^{(t)}) - f(\boldsymbol{x}^{(t+1)}).$$

对 $t = 0, \dots, T-1$ 求和，右端裂项，再用 $f(\boldsymbol{x}^{(T)}) \ge f_{\inf}$，得到

$$\frac{1}{2L}\sum_{t=0}^{T-1}\|\boldsymbol{g}^{(t)}\|_2^2 \le f(\boldsymbol{x}^{(0)}) - f_{\inf}.$$

T 项的最小值不超过平均值，这就是式 (6.8)。令 $T \to \infty$，上式说明级数 $\sum\|\boldsymbol{g}^{(t)}\|_2^2$ 收敛，所以通项趋于零。∇f 连续，极限点处的梯度等于梯度序列的极限，也就是零。 ■

定理说的是“某一步的梯度够小”，并没有说最后一步最小，所以输出时要记住梯度最小的那个迭代点。换成任意 $\alpha \in (0, 2/L)$，只需把 $1/(2L)$ 换成 $\alpha(1 - L\alpha/2)$。

用回溯时结论同样成立，只差常数。由式 (6.4)，凡是 $\alpha \le 2(1-c_1)/L$ 的步长都满足 Armijo 条件。所以若初始试探值为 α_0、每次缩短到 ρ 倍，接受的步长不低于 $\min\{\alpha_0, 2\rho(1-c_1)/L\}$，每步下降量有与上面同样形式的下界。

驻点不等于极小点。图 6.4取非凸函数 $f(\boldsymbol{x}) = -\cos x_1 + \frac{9}{2}x_2^2$，它的 Hessian 是 $\operatorname{diag}(\cos x_1, 9)$，所以 $L = 9$，下确界是 -1。从 $(\pi, 1)$ 出发的路径停在鞍点 $(\pi, 0)$，梯度为零，定理完全满足，点却不是局部最优解。稍稍偏开，从 $(3, 1)$ 出发，路径在鞍点附近徘徊一阵，再滑向真正的谷底。

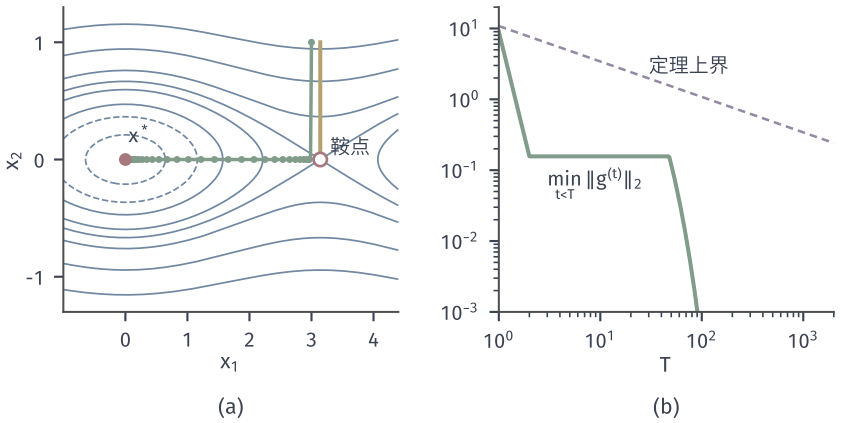


图 6.4　非凸目标 $f(\boldsymbol{x}) = -\cos x_1 + \frac{9}{2}x_2^2$ 上取 $\alpha = 1/9$ 的梯度下降。(a) 等高线与两条路径：黄色从 $(\pi, 1)$ 出发，终止于鞍点（红色空心点）；绿色从 $(3, 1)$ 出发，到达极小点（红点）。(b) 绿色路径的 $\min_{t<T}\|\boldsymbol{g}^{(t)}\|_2$（绿线），紫色虚线是式 (6.8)的上界开方。中段的平台对应在鞍点附近的徘徊。

凸情形：目标差　加上凸性后，局部的谷底就是全局的谷底，可以用目标差来衡量。关键的新工具是：切平面从下方托住目标，用它比较当前点和最优解。

定理 6.3　凸情形的梯度下降　设 f 凸，梯度 L-Lipschitz 连续，且存在最优解 $\boldsymbol{x}^\star$。取 $\alpha = 1/L$，则对任意 $T \ge 1$，

$$f(\boldsymbol{x}^{(T)}) - f^\star \le \frac{L\|\boldsymbol{x}^{(0)} - \boldsymbol{x}^\star\|_2^2}{2T}. \tag{6.9}$$

证明　记 $\boldsymbol{x} = \boldsymbol{x}^{(t)}$，$\boldsymbol{x}^+ = \boldsymbol{x}^{(t+1)}$，$\boldsymbol{g} = \boldsymbol{g}^{(t)}$。由凸性，切平面在 $\boldsymbol{x}^\star$ 处不高于目标：

$$f^\star \ge f(\boldsymbol{x}) + \boldsymbol{g}^\top(\boldsymbol{x}^\star - \boldsymbol{x}).$$

由式 (6.4)，$\alpha = 1/L$ 时单步下降至少为 $\|\boldsymbol{g}\|_2^2/(2L)$。把上式代入，得到

$$f(\boldsymbol{x}^+) - f^\star \le \boldsymbol{g}^\top(\boldsymbol{x} - \boldsymbol{x}^\star) - \frac{1}{2L}\|\boldsymbol{g}\|_2^2.$$

把 $\boldsymbol{x}^+ = \boldsymbol{x} - \boldsymbol{g}/L$ 代入距离的平方，展开得

$$\|\boldsymbol{x}^+ - \boldsymbol{x}^\star\|_2^2 = \|\boldsymbol{x} - \boldsymbol{x}^\star\|_2^2 - \frac{2}{L}\boldsymbol{g}^\top(\boldsymbol{x} - \boldsymbol{x}^\star) + \frac{1}{L^2}\|\boldsymbol{g}\|_2^2.$$

两式比较，前一式的右端恰好等于距离平方之差的 $L/2$ 倍：

$$f(\boldsymbol{x}^{(t+1)}) - f^\star \le \frac{L}{2}\Big(\|\boldsymbol{x}^{(t)} - \boldsymbol{x}^\star\|_2^2 - \|\boldsymbol{x}^{(t+1)} - \boldsymbol{x}^\star\|_2^2\Big).$$

对 $t = 0, \dots, T-1$ 求和，右端裂项，丢掉末项，得到

$$\sum_{t=1}^{T} \big(f(\boldsymbol{x}^{(t)}) - f^\star\big) \le \frac{L}{2}\|\boldsymbol{x}^{(0)} - \boldsymbol{x}^\star\|_2^2.$$

函数值逐步下降，所以最后一项是 T 项中最小的，不超过平均值，即得式 (6.9)。 ■

上面证明还顺带说明，到最优解的距离每步不增。

$1/T$ 这个阶对梯度下降不能改进。取 $f(\boldsymbol{x}) = \frac{1}{2}(Lx_1^2 + \lambda x_2^2)$, $0 < \lambda \le L$, 起点的第一坐标为 0，第二坐标为 x_0。$\alpha = 1/L$ 时目标差是 $\frac{1}{2}\lambda(1-\lambda/L)^{2T}x_0^2$。对每个给定的 T，取 $\lambda = L/(2T)$，因子 $(1-1/(2T))^{2T}$ 接近 e^{-1}，于是目标差约为

$$\frac{Lx_0^2}{4\mathrm{e}\,T}.$$

也就是说，曲率总可以小到让梯度下降在这 T 步内几乎察觉不到。这个例子的 λ 随 T 变化，它说明上界在整个函数类上的阶不能改进，并不是说某个固定的二次目标只有 $1/T$ 的速度。

强凸情形：线性收敛　再加上强凸，第 1章的结论告诉我们解存在且唯一。这时切平面之上还多出一个二次项：

$$f(\boldsymbol{y}) \ge f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})^{\top}(\boldsymbol{y} - \boldsymbol{x}) + \frac{\mu}{2}\|\boldsymbol{y} - \boldsymbol{x}\|_2^2. \tag{6.10}$$

这是一只从下方托住地面的碗，与式 (6.2)从上方扣住地面的碗相对。上下两只碗夹住地形，每步的进度就能与当前的误差比较。

定理 6.4　强凸情形的梯度下降　设 f 的梯度 L-Lipschitz 连续且满足式 (6.10)，$\mu > 0$，$\kappa = L/\mu$。取 $\alpha = 1/L$，则

$$\begin{aligned} f(\boldsymbol{x}^{(T)}) - f^\star &\le \Big(1 - \frac{1}{\kappa}\Big)^{T}\big(f(\boldsymbol{x}^{(0)}) - f^\star\big), \\ \|\boldsymbol{x}^{(T)} - \boldsymbol{x}^\star\|_2^2 &\le \Big(1 - \frac{1}{\kappa}\Big)^{T}\|\boldsymbol{x}^{(0)} - \boldsymbol{x}^\star\|_2^2. \end{aligned} \tag{6.11}$$

证明　先证梯度能控制目标差。在式 (6.10)中对 $\boldsymbol{y}$ 取右端的最小值，最小点是 $\boldsymbol{y} = \boldsymbol{x} - \nabla f(\boldsymbol{x})/\mu$，于是

$$f^\star \ge f(\boldsymbol{x}) - \frac{1}{2\mu}\|\nabla f(\boldsymbol{x})\|_2^2, \qquad \text{即} \qquad \|\nabla f(\boldsymbol{x})\|_2^2 \ge 2\mu\big(f(\boldsymbol{x}) - f^\star\big).$$

代入式 (6.4)（$\alpha = 1/L$），两边减去 $f^\star$，得到

$$f(\boldsymbol{x}^+) - f^\star \le \Big(1 - \frac{\mu}{L}\Big)\big(f(\boldsymbol{x}) - f^\star\big).$$

迭代 T 次即得第一式。

再证距离。在式 (6.10)中取 $\boldsymbol{y} = \boldsymbol{x}^\star$，整理得

$$\boldsymbol{g}^\top(\boldsymbol{x} - \boldsymbol{x}^\star) \ge f(\boldsymbol{x}) - f^\star + \frac{\mu}{2}\|\boldsymbol{x} - \boldsymbol{x}^\star\|_2^2.$$

另由 $f^\star \le f(\boldsymbol{x}^+)$ 和单步下降，得到

$$\|\boldsymbol{g}\|_2^2 \le 2L\big(f(\boldsymbol{x}) - f^\star\big).$$

把这两式代入距离平方的展开式：

$$\begin{aligned}\|\boldsymbol{x}^+ - \boldsymbol{x}^\star\|_2^2 &= \|\boldsymbol{x} - \boldsymbol{x}^\star\|_2^2 - \frac{2}{L}\boldsymbol{g}^\top(\boldsymbol{x} - \boldsymbol{x}^\star) + \frac{1}{L^2}\|\boldsymbol{g}\|_2^2 \\ &\le \Big(1 - \frac{\mu}{L}\Big)\|\boldsymbol{x} - \boldsymbol{x}^\star\|_2^2 - \frac{2}{L}\big(f(\boldsymbol{x}) - f^\star\big) + \frac{2}{L}\big(f(\boldsymbol{x}) - f^\star\big).\end{aligned}$$

后两项抵消，迭代 T 次即得第二式。 ■

用贯穿例核对。$\alpha = 1/9$ 时 $\boldsymbol{x}^{(1)} = (8, 0)$，此后第一坐标每步乘以 $8/9$，所以

$$f(\boldsymbol{x}^{(T)}) = 32\Big(\frac{64}{81}\Big)^{T-1}, \qquad T \ge 1.$$

定理的上界是 $45 \cdot (8/9)^T$，$T = 1$ 时是 40，大于真实值 32。图 6.5(a) 显示，上界比真实的衰减慢：定理覆盖所有满足条件的函数，这个二次例子并不是最坏的。

条件数怎样影响进展 三条定理合起来回答了“要多少步”。目标差达到 ε 所需的步数，凸时约为 $LR^2/(2\varepsilon)$，其中 $R = \|\boldsymbol{x}^{(0)} - \boldsymbol{x}^\star\|_2$；强凸时由 $(1 - 1/\kappa)^T \le \mathrm{e}^{-T/\kappa}$ 得到

$$T \ge \kappa \ln \frac{f(\boldsymbol{x}^{(0)}) - f^\star}{\varepsilon}.$$

所需步数与 κ 成正比。把山谷的纵横比拉大十倍，步数也大约变成十倍。图 6.5(b) 对 $\mathrm{diag}(1, \kappa)$ 实测目标差降到初值 10^{-6} 的步数，它紧贴直线 $\frac{\kappa}{4}\ln(1/\varepsilon)$。这里 $\frac{1}{4}$ 来自最佳步长：因子 $(\kappa - 1)/(\kappa + 1)$ 约为 $1 - 2/\kappa$，目标差的因子是其平方。

6.1 梯度下降
6.2 动量与加速
6.2.1 Polyak 重球法
6.2.2 Nesterov 加速梯度法
6.3 非线性共轭梯度法
6.4 收敛与计算成本
6.5 本章小结

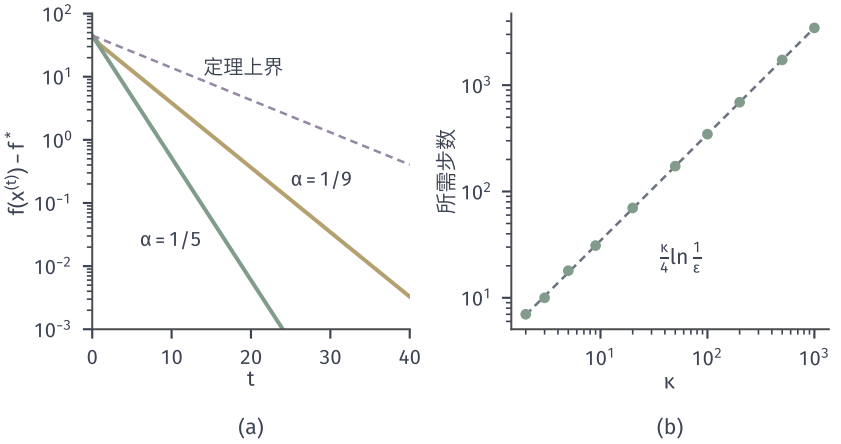


图 6.5 收敛速度与条件数。(a) 贯穿例的目标差：黄线 $\alpha = 1/9$，绿线 $\alpha = 1/5$，紫色虚线是 $\alpha = 1/L$ 时式 (6.11)的上界 $45(8/9)^t$。(b) 目标 $\frac{1}{2}(x_1^2 + \kappa x_2^2)$，起点 $(\kappa, 1)$，步长 $2/(1+\kappa)$，绿点是目标差降到初值 10^{-6} 倍的实测步数，虚线为 $\frac{\kappa}{4}\ln(1/\varepsilon)$，$\varepsilon = 10^{-6}$。

原因已经在式 (6.6)中：步长被陡峭方向限制在 $2/L$ 以内，平坦方向每步只能收缩 μ/L 量级的比例。下面的表格汇总三种情形。

表 6.1 梯度下降 $\alpha = 1/L$ 的保证，$\Delta = f(\boldsymbol{x}^{(0)}) - f_{\inf}$，$R = \|\boldsymbol{x}^{(0)} - \boldsymbol{x}^\star\|_2$。

假设	度量	上界	达到 ε 的步数
非凸，有下界	$\min_t \|\boldsymbol{g}^{(t)}\|_2^2$	$2L\Delta/T$	$2L\Delta/\varepsilon$
凸	$f(\boldsymbol{x}^{(T)}) - f^\star$	$LR^2/(2T)$	$LR^2/(2\varepsilon)$
强凸	$f(\boldsymbol{x}^{(T)}) - f^\star$	$(1-1/\kappa)^T\Delta$	$\kappa\ln(\Delta/\varepsilon)$

表中第一行的 ε 是梯度平方的容差，所以换成梯度大小达到 ε 时，步数是 $2L\Delta/\varepsilon^2$。三行的度量不同，步数不能直接相比。

6.2 动量与加速

上一节的结论是：病态目标上梯度下降的步数与 κ 成正比。不增加每步的梯度读取次数，只多用一点历史信息，能不能把这个依赖关系变小？

先看贯穿例上折返时发生了什么。图 6.6(a) 把 $\alpha = 1/5$ 的每步位移分解到两个坐标。平坦方向 x_1 上，每一步的位移都向负方向，符号一致；陡峭方向 x_2 上，位移的符号每步翻转，走过去又走回来，大部分抵消。

6.1 梯度下降
6.2 动量与加速
6.2.1 Polyak 重球法
6.2.2 Nesterov 加速梯度法
6.3 非线性共轭梯度法
6.4 收敛与计算成本
6.5 本章小结

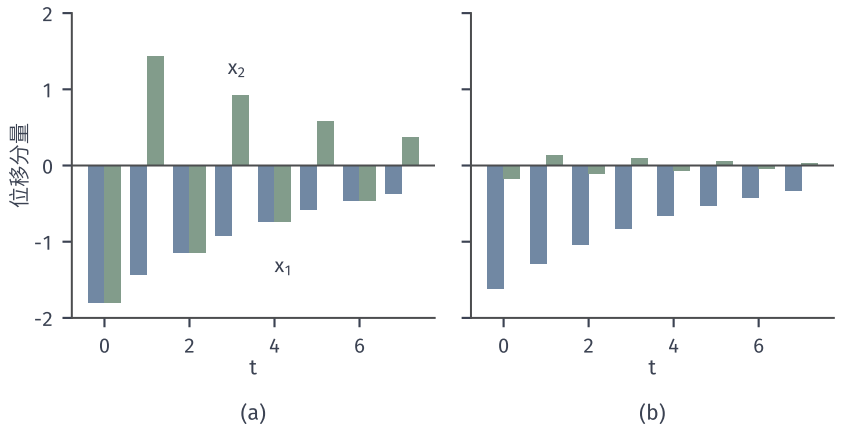


图 6.6 贯穿例上 $\alpha = 1/5$ 的梯度下降的位移。蓝色条是平坦方向 x_1 的分量，绿色条是陡峭方向 x_2 的分量。(a) 每一步的位移 $\boldsymbol{x}^{(t+1)} - \boldsymbol{x}^{(t)}$，绿色条的符号逐步交替。(b) 相邻两步位移的平均，绿色条几乎消失，蓝色条保持不变的符号与相近的大小。

图 6.6(b) 把相邻两步取平均：振荡方向互相抵消，一致方向得以保留。这就是用历史信息的线索：过去的位移本身携带了“哪些方向一直在走、哪些方向在来回”的信息，而这一信息不用额外计算梯度。

把上一步的位移乘一个系数加进当前更新，这个附加量称为**动量**（momentum）。下面两个方法都用动量，差别在梯度取在什么地方：重球法取在当前点，Nesterov 方法取在沿动量向前试探的点。

6.2.1 Polyak 重球法

主要思想 想象一个有质量的球在山谷中滚动，并受到摩擦。球的速度不会突然改变：沿谷底方向的重力持续推动，它越滚越快；沿谷壁方向的重力来回变号，速度被平均掉了。这就是想要的效果。

类比可以写成方程。位置 $\boldsymbol{x}(\tau)$ 满足

$$\ddot{\boldsymbol{x}} + a\dot{\boldsymbol{x}} + \nabla f(\boldsymbol{x}) = \boldsymbol{0},$$

其中 $a > 0$ 是摩擦系数。用步长 h 的差分代替导数：

$$\ddot{\boldsymbol{x}} \approx \frac{\boldsymbol{x}^{(t+1)} - 2\boldsymbol{x}^{(t)} + \boldsymbol{x}^{(t-1)}}{h^2}, \qquad \dot{\boldsymbol{x}} \approx \frac{\boldsymbol{x}^{(t)} - \boldsymbol{x}^{(t-1)}}{h}.$$

代入方程并整理，得到**重球法**（heavy ball method）[1]：

$$\boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} - \alpha \boldsymbol{g}^{(t)} + \beta\big(\boldsymbol{x}^{(t)} - \boldsymbol{x}^{(t-1)}\big), \tag{6.12}$$

其中 $\alpha = h^2$，$\beta = 1 - ah$。摩擦越小，β 越接近 1，历史保留得越多。类比只解释了公式的样子，它并不提供收敛保证：离散的步子可以跨过谷底，下面会看到这确实造成困难。

[1] B. T. Polyak, *Some Methods of Speeding up the Convergence of Iteration Methods* In USSR Computational Mathematics and Mathematical Physics, 1964, vol. 4, no. 5, pp. 1–17

α 和 β 怎样选？在正定二次目标上可以精确分析。与梯度下降一样，取 $\boldsymbol{H}$ 的特征方向作坐标，由式 (6.12)，特征值 λ 对应的误差分量满足二阶递推

$$e_\lambda^{(t+1)} = (1 + \beta - \alpha\lambda) e_\lambda^{(t)} - \beta e_\lambda^{(t-1)}. \tag{6.13}$$

二阶线性递推的行为由特征方程的两个根决定：

$$r^2 - (1 + \beta - \alpha\lambda) r + \beta = 0. \tag{6.14}$$

两根之积是 β。判别式小于零时两根共轭，模相等，所以模都等于 $\sqrt{\beta}$，与 λ 无关。这是重球法最关键的现象：梯度下降的因子 $1 - \alpha\lambda$ 随方向变化，动量却可以把一段特征值的收缩速度拉平。

判别式小于等于零，就是 $|1 + \beta - \alpha\lambda| \le 2\sqrt{\beta}$。把它拆成上下两个不等式，并用 $1 + \beta \mp 2\sqrt{\beta} = (1 \mp \sqrt{\beta})^2$，得到

$$(1 - \sqrt{\beta})^2 \le \alpha\lambda \le (1 + \sqrt{\beta})^2. \tag{6.15}$$

落在这个区间内的 λ，收缩因子都是 $\sqrt{\beta}$；落在区间外时两根是实数，积为 β，其中一个的绝对值大于 $\sqrt{\beta}$，收缩变慢。

于是设计问题变得清楚：让 $[\alpha\mu, \alpha L]$ 全部落入区间 (6.15)，同时让 $\sqrt{\beta}$ 尽量小。β 越小区间越窄，所以最优时区间的两端恰好卡住，

$$(1 - \sqrt{\beta})^2 = \alpha\mu, \qquad (1 + \sqrt{\beta})^2 = \alpha L.$$

两式开方后相除，得到 $\sqrt{\kappa} = (1 + \sqrt{\beta})/(1 - \sqrt{\beta})$，解出 $\sqrt{\beta}$；两式开方后相加，得到 $\sqrt{\alpha L} + \sqrt{\alpha\mu} = 2$，解出 α。结果是

$$\alpha = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \qquad \beta = \Big(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}\Big)^2. \tag{6.16}$$

收缩因子 $\sqrt{\beta} = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ 的形式与梯度下降相同，只是 κ 换成了 $\sqrt{\kappa}$。

例中 $L = 9$，$\mu = 1$，$\sqrt{\kappa} = 3$，所以

$$\alpha = \frac{4}{(3 + 1)^2} = \frac{1}{4}, \qquad \beta = \Big(\frac{2}{4}\Big)^2 = \frac{1}{4}, \qquad \sqrt{\beta} = \frac{1}{2}.$$

图 6.7(a) 画出 λ 从 1 走到 9 时根的运动。$\lambda = 1$ 时是实轴上的二重根 $\frac{1}{2}$，随着 λ 增大，两根沿半径 $\frac{1}{2}$ 的圆分开，在 $\lambda = 5$ 时到达 $\pm\frac{1}{2}\mathrm{i}$，再在 $\lambda = 9$ 时汇合于 $-\frac{1}{2}$。梯度下降的单根则在实轴上从 0.8 移动到 -0.8。图 6.7(b) 把模按 λ 展开：梯度下降是 V 形，重球法是平底。

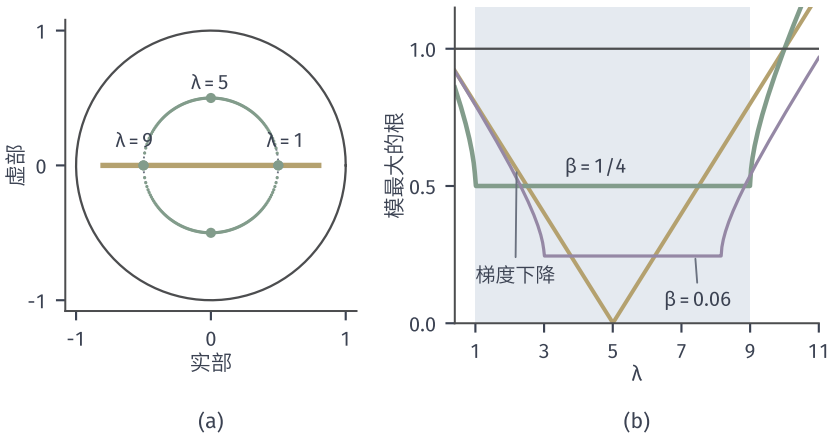


图 6.7 重球法的特征根。(a)$\alpha=\beta=1/4$ 时，$\lambda\in[1,9]$ 对应的根（绿色）落在半径 $1/2$ 的圆上；黄色线段是 $\alpha=1/5$ 的梯度下降的根 $1-\alpha\lambda$；外圈是单位圆。(b) 模最大的根关于 λ 的变化，蓝底区间是 $[\mu,L]$。绿线 $\alpha=\beta=1/4$ 的平底宽度正好覆盖 $[1,9]$；黄线是 $\alpha=1/5$ 的梯度下降；紫线取 $\alpha=0.19$，$\beta=0.06$，平底变低却变窄，靠近区间两端时被实根抬高。

变量

- $\boldsymbol{x}^{(t)},\boldsymbol{x}^{(t-1)}\in\mathbb{R}^n$：当前点与上一点，比梯度下降多存一个向量。
- $\boldsymbol{g}^{(t)}\in\mathbb{R}^n$：当前点的梯度。
- $\alpha>0$，$0\le\beta<1$：步长与动量系数，全程固定。
- ε，T：容差与最大步数。

初始化 规定 $\boldsymbol{x}^{(-1)}=\boldsymbol{x}^{(0)}$，于是第一步没有动量，就是一步梯度下降。按式 (6.16)确定参数。例中 $\alpha=\beta=1/4$，容差 $\varepsilon=10^{-3}$，起点仍是

$$\boldsymbol{x}^{(-1)}=\boldsymbol{x}^{(0)}=(9,1).$$

每轮更新　在第 t 轮：

1. **读取梯度并检查停止**。计算 $\boldsymbol{g}^{(t)}$；若 $\|\boldsymbol{g}^{(t)}\|_2 \le \varepsilon$ 或 $t = T$，输出 $\boldsymbol{x}^{(t)}$。例中第一轮
$$\boldsymbol{g}^{(0)} = (9, 9), \qquad \|\boldsymbol{g}^{(0)}\|_2 \approx 12.73.$$

2. **计算动量项**。令 $\boldsymbol{m}^{(t)} = \beta(\boldsymbol{x}^{(t)} - \boldsymbol{x}^{(t-1)})$。例中第一轮
$$\boldsymbol{m}^{(0)} = \boldsymbol{0}.$$

3. **更新**。按式 (6.12)把负梯度步和动量项加到 $\boldsymbol{x}^{(t)}$ 上，令 $t \leftarrow t + 1$。例中第一轮
$$\boldsymbol{x}^{(1)} = (9, 1) - \tfrac{1}{4}(9, 9) = (6.75, -1.25), \qquad f(\boldsymbol{x}^{(1)}) = 29.8125.$$
例中第二轮，梯度和动量项分别是
$$\boldsymbol{g}^{(1)} = (6.75, -11.25), \qquad \boldsymbol{m}^{(1)} = \tfrac{1}{4}(-2.25, -2.25) = (-0.5625, -0.5625),$$
于是
$$\boldsymbol{x}^{(2)} = (6.75, -1.25) - (1.6875, -2.8125) + (-0.5625, -0.5625) = (4.5, 1),$$
$f(\boldsymbol{x}^{(2)}) = 14.625$。
例中第三轮，梯度和动量项分别是
$$\boldsymbol{g}^{(2)} = (4.5, 9), \qquad \boldsymbol{m}^{(2)} = \tfrac{1}{4}(-2.25, 2.25) = (-0.5625, 0.5625),$$
于是
$$\boldsymbol{x}^{(3)} = (4.5, 1) - (1.125, 2.25) + (-0.5625, 0.5625) = (2.8125, -0.6875),$$
$f(\boldsymbol{x}^{(3)}) \approx 6.082$。比较梯度下降的第三步 $f \approx 11.80$，已经差了将近一半。

在这个例子上，式 (6.14)的根是二重的：$\lambda = 1$ 时为 $\frac{1}{2}$，$\lambda = 9$ 时为 $-\frac{1}{2}$。二重根的递推解是 $(a + bt)r^t$，由前两项定出系数，两个坐标是
$$x_1^{(t)} = \frac{9 + 4.5t}{2^t}, \qquad x_2^{(t)} = (1 + 1.5t)\Big(-\frac{1}{2}\Big)^t. \tag{6.17}$$

代入 $t = 19$，梯度大小约为 5.4×10^{-4}，$t = 18$ 时仍大于 10^{-3}，于是第 19 步满足容差并结束。最终得到
$$\boldsymbol{x}^{(19)} \approx (1.80 \times 10^{-4},\ -5.63 \times 10^{-5}).$$

同样的容差，梯度下降 $\alpha = 1/5$ 需要 43 步。

二次目标上的收敛 式 (6.17)中的 $1 + 1.5t$ 值得留意：根是二重时，收敛并不是纯粹的 ρ^t，前面还有一个线性增长的因子。下面的定理把它显式写出来。

定理 6.5 正定二次目标上的重球法 设 f 是 Hessian 为 $\boldsymbol{H}$ 的二次目标，最优解为 $\boldsymbol{x}^\star$，$\boldsymbol{H}$ 对称正定，特征值落在 $[\mu, L]$ 内，$\kappa = L/\mu > 1$。按式 (6.16)取参数，令 $\boldsymbol{x}^{(-1)} = \boldsymbol{x}^{(0)}$，$\rho = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$，则

$$\|\boldsymbol{x}^{(t)} - \boldsymbol{x}^\star\|_2 \le (2t + 1)\rho^t \|\boldsymbol{x}^{(0)} - \boldsymbol{x}^\star\|_2. \tag{6.18}$$

证明 由式 (6.15)及参数的取法，每个特征值对应的两根 r_1, r_2 的模都等于 ρ，并且 $r_1 + r_2 = 1 + \beta - \alpha\lambda$，$r_1 r_2 = \beta = \rho^2$。

定义 $S_k = \sum_{j=0}^{k} r_1^j r_2^{k-j}$，规定 $S_{-1} = 0$。由定义有 $S_{k+1} = r_1 S_k + r_2^{k+1}$，同理 $S_k = r_1 S_{k-1} + r_2^k$。把第二式乘以 r_2 后代入第一式，得到

$$S_{k+1} = (r_1 + r_2) S_k - r_1 r_2 S_{k-1}.$$

所以 S_t 满足递推 (6.13)。分量的解可以写成 $e^{(t)} = S_t e^{(0)} - \beta S_{t-1} e^{(-1)}$：它满足同一递推，而 $t = 0$ 和 $t = 1$ 时分别等于 $e^{(0)}$ 和式 (6.13)的右端。

由 $e^{(-1)} = e^{(0)}$，$|S_k| \le (k+1)\rho^k$ 和 $\beta = \rho^2$，

$$|e^{(t)}| \le \big((t+1)\rho^t + \rho^2\, t\, \rho^{t-1}\big)|e^{(0)}| \le (2t+1)\rho^t |e^{(0)}|,$$

最后一步用了 $\rho < 1$。对所有特征方向平方求和，再用标准正交变换保持长度，即得结论。 ■

证明中间一步的界是 $(t + 1 + \rho t)\rho^t$。例中 $\rho = \frac{1}{2}$，第二坐标恰好取到这个界，即 $(1 + 1.5t)2^{-t}$，与式 (6.17)相符。图 6.8(b) 展示了多项式因子的后果：比值 $x_2^{(t)}/x_2^{(0)}$ 第一步到达 -1.25，比初值还大，随后才在紫色包络线外侧逐渐衰减。

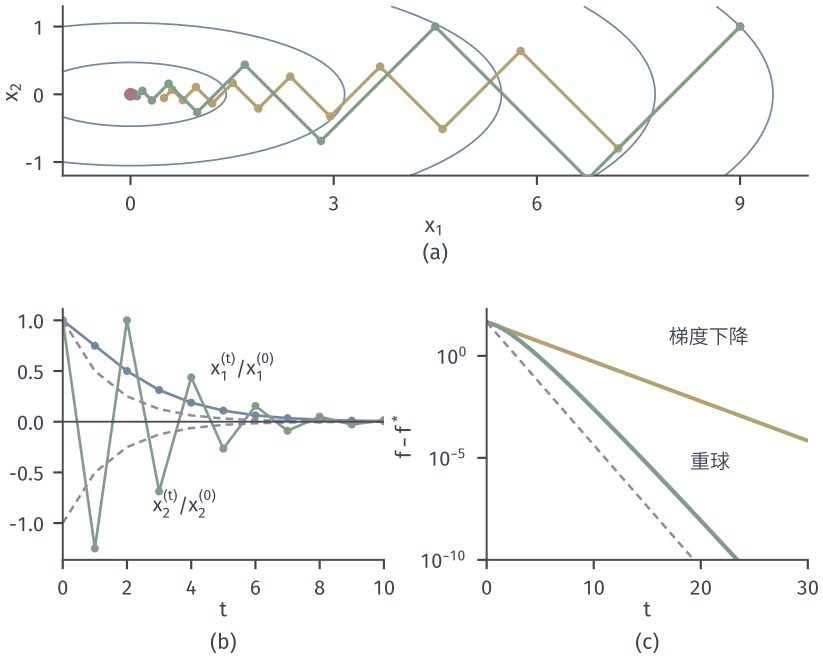


图 6.8 贯穿例上的重球法（绿色，$\alpha = \beta = 1/4$）与梯度下降（黄色，$\alpha = 1/5$）。(a) 等高线上的前 14 步。(b) 重球法两坐标相对初值的比，式 (6.17)，紫色虚线是 $\pm\rho^t$。(c) 目标差的半对数曲线，紫色虚线是 $45\rho^{2t}$，绿线在上方平行，差别来自多项式因子。

所以，用 ρ 比较两种方法时，要记住它是渐近的说法。达到相对精度 ε 的步数约为 $\frac{\sqrt{\kappa}}{2}\ln(1/\varepsilon)$，与梯度下降的 $\frac{\kappa}{2}\ln(1/\varepsilon)$ 相比，$\kappa = 10^4$ 时大约快一百倍。

参数的稳定范围 这个加速依赖于参数对 L 和 μ 的准确了解。由递推 (6.13)的两根都在单位圆内的条件，可以写出稳定范围。多项式 $p(r) = r^2 - (1 + \beta - \alpha\lambda)r + \beta$ 满足 $p(1) = \alpha\lambda$，$p(-1) = 2(1 + \beta) - \alpha\lambda$，在 $\beta \geq 0$ 时，两根都在单位圆内当且仅当

$$\beta < 1, \qquad 0 < \alpha\lambda < 2(1 + \beta). \tag{6.19}$$

判据是 $p(1) > 0$，$p(-1) > 0$，且根之积 β 的绝对值小于 1。例中若沿用 $\alpha = 1/4$，却把 β 减到 0.06，则 $\alpha L = 2.25$ 大于 $2(1 + \beta) = 2.12$，陡峭方向发散。动量不只是“加速的旋钮”，它也放宽了步长的稳定界限，两个参数必须一起调。

离开二次目标 式 (6.16)的推导完全依赖于每个方向有固定的 λ。目标不是二次时，局部曲率随位置变化，没有固定的特征方向。若 f 二阶连续可

微，而 $\boldsymbol{x}^\star$ 处的 Hessian 特征值落在 $[\mu, L]$ 内，在 $\boldsymbol{x}^\star$ 足够近处迭代可以用线性化来分析，局部收敛速度接近 ρ；这是局部结论，对起点有要求。

全局情形下，这组参数确实可能失败。考虑一元函数，其导数分三段：

$$f'(x) = \begin{cases} 25x, & x < 1, \\ x + 24, & 1 \le x < 2, \\ 25x - 24, & x \ge 2. \end{cases} \tag{6.20}$$

三段在分界点处衔接，f' 连续且斜率都在 $[1, 25]$ 内，所以 f 强凸，$\mu = 1$，$L = 25$，最优解是 $x^\star = 0$。二次目标的最优参数是 $\alpha = 1/9$，$\beta = 4/9$。

这组参数有一个周期为 3 的轨道，不会收敛：

$$x \text{ 依次取 } \quad \frac{792}{1225}, \quad -\frac{2208}{1225}, \quad \frac{2592}{1225}.$$

可以逐步核对。从前两点 2592/1225（上一点）和 792/1225（当前点）出发，当前点小于 1，导数是 $25x$。代入式 (6.12)并把分母提出来：

$$x^+ = \frac{1}{1225}\Big(792 - \frac{25 \cdot 792}{9} + \frac{4}{9}(792 - 2592)\Big) = -\frac{2208}{1225}.$$

下一步当前点 $-2208/1225$ 仍小于 1，同样算得 2592/1225。再下一步，当前点约为 2.116，落在第三段，导数 $25x - 24$ 多出的常数 -24 提供了回拉，算得的新点恰好回到 792/1225。

图 6.9展示了 $x^{(0)} = 3.3$ 时的情形：迭代很快落到这个周期上。作为对照，下一小节的方法在同一函数上正常收敛。这个反例说明，正定二次目标上的最优参数不能直接移到一般强凸目标上，也不能因此宣称全局加速。

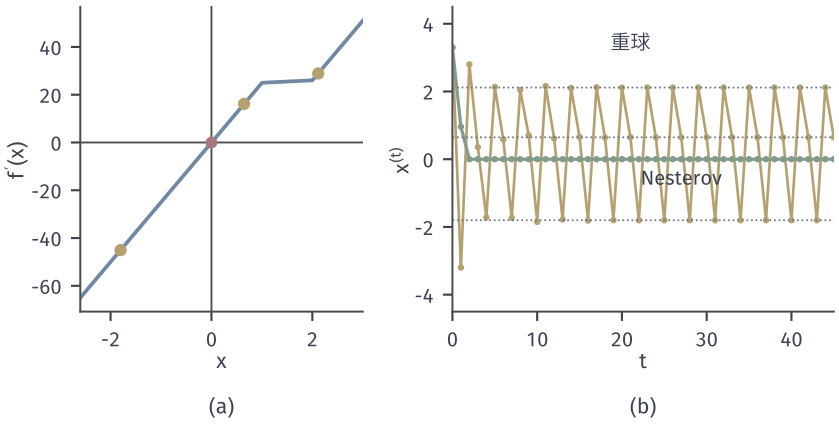


图 6.9　强凸光滑目标上重球法不收敛的例子。(a) 式 (6.20)的导数 $f'(x)$（蓝线），红点是最优解，黄点是周期轨道的三个点。(b) 从 $x^{(0)} = 3.3$ 出发的迭代，黄线是重球法（$\alpha = 1/9$，$\beta = 4/9$），落到灰色点线标出的周期上；绿线是 $\alpha = 1/25$，$\beta = 2/3$ 的 Nesterov 方法，收敛到 0。

6.1 梯度下降
6.2 动量与加速
6.2.1 Polyak 重球法
6.2.2 Nesterov 加速梯度法
6.3 非线性共轭梯度法
6.4 收敛与计算成本
6.5 本章小结

对一般强凸目标，缩小参数可以恢复全局收敛，但已知的这类分析一般达不到 $\sqrt{\kappa}$ 的依赖，具体的条件和常数需要逐项核对，证明较长，读者可查阅一阶方法的专门文献。本章只在正定二次目标上给重球法下定量结论。

6.2.2 Nesterov 加速梯度法

主要思想 重球法的动量盲目地累加：梯度在当前点读取，动量推出的位置却没有被检查，步子跨过谷底时也不会被纠正。一个自然的改进是把两件事的次序换一下：先顺着动量探出去，到探出的位置上再看坡度，用那里的梯度来修正。

这就是Nesterov 加速梯度法（Nesterov accelerated gradient）[2]。

它先由当前与历史迭代构成**外推点**（extrapolation point）$\boldsymbol{y}^{(t)}$，再在外推点做一步梯度下降：

$$\begin{aligned} \boldsymbol{y}^{(t)} &= \boldsymbol{x}^{(t)} + \beta^{(t)}\big(\boldsymbol{x}^{(t)} - \boldsymbol{x}^{(t-1)}\big), \\ \boldsymbol{x}^{(t+1)} &= \boldsymbol{y}^{(t)} - \alpha \nabla f(\boldsymbol{y}^{(t)}). \end{aligned} \tag{6.21}$$

与式 (6.12)比较，只有梯度的计算位置不同。图 6.10把一步的结构并排画出。

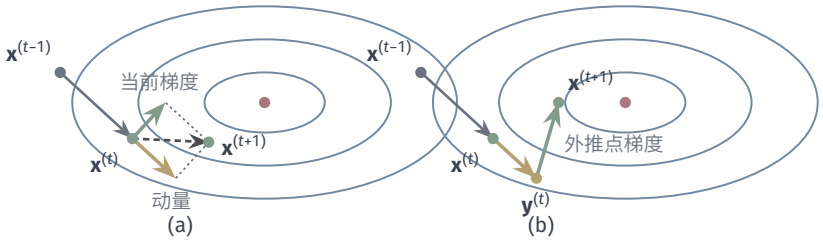


图 6.10 一步更新的结构对比，蓝色椭圆是等高线，红点是最优解。(a) 重球法：动量（黄）和当前点的负梯度（绿）都从 $\boldsymbol{x}^{(t)}$ 出发，两者相加得到新点。(b)Nesterov 方法：先沿动量走到外推点 $\boldsymbol{y}^{(t)}$，再从那里走一步负梯度。外推点已经冲到谷壁的外侧，那里的梯度把步子拉回。

用二次目标看这一改变的效果。代入 $\nabla f(\boldsymbol{y}) = \boldsymbol{H}(\boldsymbol{y} - \boldsymbol{x}^\star)$，并在特征方向上写开，记 $s = 1 - \alpha\lambda$，得到

$$e_\lambda^{(t+1)} = s\Big((1+\beta)e_\lambda^{(t)} - \beta e_\lambda^{(t-1)}\Big). \tag{6.22}$$

对照式 (6.13)。重球法的 $-\beta e^{(t-1)}$ 不受 λ 影响，动量对各方向一视同仁；这里动量也被乘了 s，曲率大的方向 s 小，动量被自动压低。这就是“外推点的梯度纠正动量”在公式上的含义。

特征方程是 $r^2 - s(1+\beta)r + s\beta = 0$。复根时两根的积等于模的平方，所以模是 $\sqrt{s\beta}$，随 λ 的增大而减小。

[2] Y. Nesterov, *A Method for Solving the Convex Programming Problem with Convergence Rate $O(1/k^2)$* In Soviet Mathematics Doklady, 1983, vol. 27, no. 2, pp. 372–376

参数怎样选？取 $\alpha = 1/L$。例如强凸时取

$$\beta = \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}. \tag{6.23}$$

于是最平坦的方向 $\lambda = \mu$ 上，$s = 1 - 1/\kappa$，判别式恰好为零，二重根是 $1 - 1/\sqrt{\kappa}$。由 $(1+\beta)^2 s = 4\beta$ 可以直接验证这一点：把 β 代入，$(1+\beta) = 2\sqrt{\kappa}/(\sqrt{\kappa}+1)$，$4\beta/(1+\beta)^2 = (\kappa-1)/\kappa = s$。

而光滑凸时，μ 不可用，系数要随步数增长，后文的定理将说明它的具体形式。例中 $\sqrt{\kappa} = 3$，

$$\alpha = \frac{1}{9}, \qquad \beta = \frac{1}{2}, \qquad 1 - \frac{1}{\sqrt{\kappa}} = \frac{2}{3}.$$

变量

- $\boldsymbol{x}^{(t)}, \boldsymbol{x}^{(t-1)} \in \mathbb{R}^n$：当前点与上一点。
- $\boldsymbol{y}^{(t)} \in \mathbb{R}^n$：外推点，梯度在这里读取，用后可覆盖。
- α，$\beta^{(t)}$：步长和外推系数。
- ε，T：容差与最大步数。

初始化 令 $\boldsymbol{x}^{(-1)} = \boldsymbol{x}^{(0)}$，于是 $\boldsymbol{y}^{(0)} = \boldsymbol{x}^{(0)}$。例中 $\alpha = 1/9$，$\beta = 1/2$，容差 $\varepsilon = 10^{-3}$，

$$\boldsymbol{y}^{(0)} = \boldsymbol{x}^{(0)} = (9, 1).$$

每轮更新 在第 t 轮：

1. **外推**。由式 (6.21)的第一行计算 $\boldsymbol{y}^{(t)}$。例中第一轮

$$\boldsymbol{y}^{(0)} = (9, 1).$$

2. **读取外推点梯度并更新**。由式 (6.21)的第二行计算 $\boldsymbol{x}^{(t+1)}$。例中第一轮

$$\nabla f(\boldsymbol{y}^{(0)}) = (9, 9), \qquad \boldsymbol{x}^{(1)} = (9, 1) - \tfrac{1}{9}(9, 9) = (8, 0).$$

例中第二轮的外推点和梯度是

$$\boldsymbol{y}^{(1)} = (8, 0) + \tfrac{1}{2}(-1, -1) = (7.5, -0.5), \qquad \nabla f(\boldsymbol{y}^{(1)}) = (7.5, -4.5),$$

于是

$$\boldsymbol{x}^{(2)} = (7.5, -0.5) - \tfrac{1}{9}(7.5, -4.5) = \left(\tfrac{20}{3}, 0\right).$$

例中第三轮的外推点和梯度是

$$\boldsymbol{y}^{(2)} = \left(\tfrac{20}{3}, 0\right) + \tfrac{1}{2}\left(-\tfrac{4}{3}, 0\right) = (6, 0), \qquad \nabla f(\boldsymbol{y}^{(2)}) = (6, 0),$$

于是

$$\boldsymbol{x}^{(3)} = (6, 0) - \tfrac{1}{9}(6, 0) = \left(\tfrac{16}{3}, 0\right).$$

3. **检查停止**。若新点的梯度大小不超过 ε 或已达 T 步，输出 $\boldsymbol{x}^{(t+1)}$。这一检查要在 $\boldsymbol{x}^{(t+1)}$ 处多读一次梯度，实际计算中常改用外推点的梯度大小，或每隔若干步才检查。例中第三轮 $\|\nabla f(\boldsymbol{x}^{(3)})\|_2 \approx 5.33$，继续。

例中第二坐标在第一步之后就是零，原因是陡峭方向 $\lambda = L$ 上 $s = 0$，由式 (6.22)，下一步的误差直接等于零。平坦方向的递推是 $e^{(t+1)} = \tfrac{4}{3}e^{(t)} - \tfrac{4}{9}e^{(t-1)}$，二重根是 $\tfrac{2}{3}$，解出

$$x_1^{(t)} = (9 + 3t)\left(\frac{2}{3}\right)^t, \qquad x_2^{(t)} = 0 \quad (t \geq 1). \tag{6.24}$$

代入式 (6.24)，第 29 步首次满足容差。最终得到

$$\boldsymbol{x}^{(29)} \approx (7.51 \times 10^{-4},\ 0).$$

强凸情形的势函数分析　图 6.11(b) 比较了三种方法在例中各方向上的根，(c) 是目标差。在这个二次例子上，重球法的因子 $\tfrac{1}{2}$ 比 Nesterov 方法的 $\tfrac{2}{3}$ 更小，步数 19 也少于 29。Nesterov 方法的价值不在于二次目标上最快，而在于它的保证可以一直延伸到一般的强凸光滑目标，而这正是重球法在式 (6.20)中失败的地方。

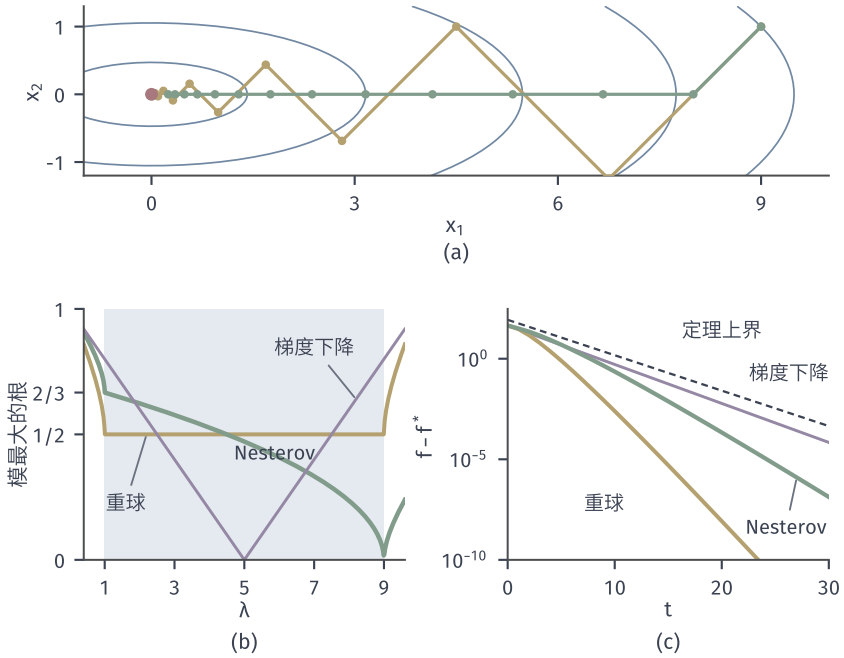


图 6.11　贯穿例上的 Nesterov 方法（绿色，$\alpha = 1/9$，$\beta = 1/2$），对照重球法（黄色，$\alpha = \beta = 1/4$）和梯度下降（紫色，$\alpha = 1/5$）。(a) 等高线上的前 14 步。(b) 模最大的根关于 λ 的变化，蓝底区间是 $[\mu, L]$。(c) 目标差，黑色虚线是式 (6.27)给出的上界 $86(2/3)^t$。

要在一般目标上证明收敛，不能再用特征分解，也不能指望函数值单调下降：动量可能把函数值暂时抬高。需要另找一个每步都下降的量，称为**势函数**（potential function）。它把“函数值的差”和“某个辅助点到解的距离”加起来，走动时一项增大可以由另一项吸收。

设 $q = 1/\sqrt{\kappa} = \sqrt{\mu/L}$，引入辅助点序列 $\boldsymbol{v}^{(0)} = \boldsymbol{x}^{(0)}$，

$$\boldsymbol{v}^{(t+1)} = \boldsymbol{x}^{(t)} + \frac{1}{q}\big(\boldsymbol{x}^{(t+1)} - \boldsymbol{x}^{(t)}\big). \tag{6.25}$$

它是沿本步位移放大 $1/q$ 倍得到的“更大胆的点”。

定理 6.6　强凸情形的 Nesterov 方法　设 f 的梯度 L-Lipschitz 连续且 μ 强凸，$\mu > 0$。取 $\alpha = 1/L$ 和式 (6.23)的常数 β，$\boldsymbol{x}^{(-1)} = \boldsymbol{x}^{(0)}$。则势函数

$$\Phi^{(t)} = f(\boldsymbol{x}^{(t)}) - f^\star + \frac{\mu}{2}\|\boldsymbol{v}^{(t)} - \boldsymbol{x}^\star\|_2^2 \tag{6.26}$$

满足 $\Phi^{(t+1)} \le (1 - 1/\sqrt{\kappa})\Phi^{(t)}$，因此

$$f(\boldsymbol{x}^{(T)}) - f^\star \le \Big(1 - \frac{1}{\sqrt{\kappa}}\Big)^T \Big(f(\boldsymbol{x}^{(0)}) - f^\star + \frac{\mu}{2}\|\boldsymbol{x}^{(0)} - \boldsymbol{x}^\star\|_2^2\Big). \tag{6.27}$$

证明　固定一步，省略上标 (t)，记 $\boldsymbol{g}=\nabla f(\boldsymbol{y})$，$\boldsymbol{x}^{+}$ 和 $\boldsymbol{v}^{+}$ 为下一步的点。先把辅助点写成便于计算的形式。

第一步，验证两个恒等式：

$$\boldsymbol{y}=\frac{\boldsymbol{x}+q\boldsymbol{v}}{1+q},\qquad \boldsymbol{v}^{+}=(1-q)\boldsymbol{v}+q\boldsymbol{y}-\frac{q}{\mu}\boldsymbol{g}.$$

第一式在 $t=0$ 时成立。设它对 t 成立，则 $q\boldsymbol{v}=(1+q)\boldsymbol{y}-\boldsymbol{x}$，代入第二式右端，并用 $\frac{q}{\mu}=\frac{1}{qL}$ 和 $\boldsymbol{x}^{+}=\boldsymbol{y}-\boldsymbol{g}/L$，化简得到

$$\frac{1}{q}\big(\boldsymbol{x}^{+}-(1-q)\boldsymbol{x}\big)=\boldsymbol{x}+\frac{1}{q}(\boldsymbol{x}^{+}-\boldsymbol{x}),$$

正是式 (6.25)。再把 $\boldsymbol{v}^{+}$ 代入 $(\boldsymbol{x}^{+}+q\boldsymbol{v}^{+})/(1+q)$，得到

$$\boldsymbol{x}^{+}+\frac{1-q}{1+q}(\boldsymbol{x}^{+}-\boldsymbol{x})=\boldsymbol{y}^{(t+1)},$$

所以第一式对 $t+1$ 成立；这里用到 $\beta=(1-q)/(1+q)$，它就是式 (6.23)。

第二步，估计距离项。记 $\boldsymbol{w}=(1-q)\boldsymbol{v}+q\boldsymbol{y}$，则 $\boldsymbol{v}^{+}=\boldsymbol{w}-\frac{q}{\mu}\boldsymbol{g}$，展开平方并乘 $\frac{\mu}{2}$：

$$\frac{\mu}{2}\|\boldsymbol{v}^{+}-\boldsymbol{x}^{\star}\|_2^2=\frac{\mu}{2}\|\boldsymbol{w}-\boldsymbol{x}^{\star}\|_2^2-q\boldsymbol{g}^{\top}(\boldsymbol{w}-\boldsymbol{x}^{\star})+\frac{q^2}{2\mu}\|\boldsymbol{g}\|_2^2.$$

第三步，函数项。由下降引理，外推点走一步满足

$$f(\boldsymbol{x}^{+})\le f(\boldsymbol{y})-\frac{1}{2L}\|\boldsymbol{g}\|_2^2.$$

又 $q^2/(2\mu)=1/(2L)$，两边的 $\|\boldsymbol{g}\|_2^2$ 恰好抵消。再用平方范数的凸性拆开 $\boldsymbol{w}$，得到

$$\Phi^{(t+1)}\le f(\boldsymbol{y})-f^{\star}+(1-q)\frac{\mu}{2}\|\boldsymbol{v}-\boldsymbol{x}^{\star}\|_2^2+q\frac{\mu}{2}\|\boldsymbol{y}-\boldsymbol{x}^{\star}\|_2^2-q\boldsymbol{g}^{\top}(\boldsymbol{w}-\boldsymbol{x}^{\star}).$$

第四步，处理内积。把 $\boldsymbol{w}-\boldsymbol{x}^{\star}$ 拆开：

$$\boldsymbol{w}-\boldsymbol{x}^{\star}=(1-q)(\boldsymbol{v}-\boldsymbol{y})+(\boldsymbol{y}-\boldsymbol{x}^{\star}).$$

对后一部分用强凸性：

$$q\boldsymbol{g}^{\top}(\boldsymbol{y}-\boldsymbol{x}^{\star})\ge q\big(f(\boldsymbol{y})-f^{\star}\big)+q\frac{\mu}{2}\|\boldsymbol{y}-\boldsymbol{x}^{\star}\|_2^2.$$

代入后，$\|\boldsymbol{y}-\boldsymbol{x}^\star\|_2^2$ 项抵消，留下

$$\Phi^{(t+1)} \le (1-q)\big(f(\boldsymbol{y})-f^\star\big) + (1-q)\frac{\mu}{2}\|\boldsymbol{v}-\boldsymbol{x}^\star\|_2^2 - q(1-q)\boldsymbol{g}^\top(\boldsymbol{v}-\boldsymbol{y}).$$

第五步，由第一式 $q(\boldsymbol{v}-\boldsymbol{y}) = \boldsymbol{y}-\boldsymbol{x}$，末项等于 $(1-q)\boldsymbol{g}^\top(\boldsymbol{x}-\boldsymbol{y})$。凸性给出

$$\boldsymbol{g}^\top(\boldsymbol{x}-\boldsymbol{y}) \le f(\boldsymbol{x}) - f(\boldsymbol{y}),$$

于是 $f(\boldsymbol{y})$ 消去，

$$\Phi^{(t+1)} \le (1-q)\Big(f(\boldsymbol{x}) - f^\star + \frac{\mu}{2}\|\boldsymbol{v}-\boldsymbol{x}^\star\|_2^2\Big) = (1-q)\Phi^{(t)}.$$

由 $\boldsymbol{v}^{(0)} = \boldsymbol{x}^{(0)}$，迭代得

$$f(\boldsymbol{x}^{(T)}) - f^\star \le \Phi^{(T)} \le (1-q)^T \Phi^{(0)}.$$

■

用贯穿例核对势函数。$\mu = 1$，$q = \tfrac{1}{3}$，辅助点由式 (6.25)算出，三个势函数值依次是

$$\begin{aligned} \boldsymbol{v}^{(0)} &= (9,1), & \Phi^{(0)} &= 45 + 41 = 86,\\ \boldsymbol{v}^{(1)} &= (6,-2), & \Phi^{(1)} &= 32 + 20 = 52,\\ \boldsymbol{v}^{(2)} &= (4,0), & \Phi^{(2)} &\approx 22.22 + 8 = 30.22. \end{aligned}$$

定理要求每步至少缩小到 $\tfrac{2}{3}$：$86\cdot\tfrac{2}{3} \approx 57.3 \ge 52$，$52\cdot\tfrac{2}{3} \approx 34.7 \ge 30.22$。

强凸性给出距离项不超过初始目标差，所以式 (6.27)右端不超过初始目标差的 $2(1-1/\sqrt{\kappa})^T$ 倍。所以达到目标差 ε 的步数约为 $\sqrt{\kappa}\ln(1/\varepsilon)$，与重球法在二次目标上的量级相同，但条件只要求一般的强凸光滑。式 (6.20)满足这些条件，定理保证了图 6.9中绿线的收敛。

光滑凸情形的势函数分析　没有强凸常数时，常数的 β 无从定义。这时让外推系数随步数增长。定义

$$\theta^{(0)} = 1, \qquad \theta^{(t+1)} = \frac{1+\sqrt{1+4(\theta^{(t)})^2}}{2}, \qquad \beta^{(t+1)} = \frac{\theta^{(t)}-1}{\theta^{(t+1)}}, \tag{6.28}$$

并取 $\beta^{(0)} = 0$，$\alpha = 1/L$。$\theta^{(t+1)}$ 是方程 $\theta^2 - \theta = (\theta^{(t)})^2$ 的正根，这个关系在证明中恰好让相邻两项抵消。由 $\theta^{(t+1)} \ge \theta^{(t)} + \tfrac{1}{2}$ 得 $\theta^{(t)} \ge (t+2)/2$，系数 $\beta^{(t)}$ 逐步趋近于 1。

定理 6.7　光滑凸情形的 Nesterov 方法　设 f 凸，梯度 L-Lipschitz 连续，存在最优解 $\boldsymbol{x}^\star$。按式 (6.21)、(6.28)迭代，$\alpha = 1/L$，则对任意 $T \geq 1$，

$$f(\boldsymbol{x}^{(T)}) - f^\star \leq \frac{2L\|\boldsymbol{x}^{(0)} - \boldsymbol{x}^\star\|_2^2}{(T+1)^2}. \tag{6.29}$$

证明　第一步，建立一个单步不等式。设 $\boldsymbol{y}$ 任意，$\boldsymbol{x}^+ = \boldsymbol{y} - \nabla f(\boldsymbol{y})/L$，$\boldsymbol{z}$ 任意。由下降引理和凸性，

$$f(\boldsymbol{x}^+) \leq f(\boldsymbol{z}) + \nabla f(\boldsymbol{y})^\top(\boldsymbol{y} - \boldsymbol{z}) - \frac{1}{2L}\|\nabla f(\boldsymbol{y})\|_2^2.$$

把 $\nabla f(\boldsymbol{y}) = L(\boldsymbol{y} - \boldsymbol{x}^+)$ 代入，并用恒等式

$$2\boldsymbol{a}^\top\boldsymbol{b} - \|\boldsymbol{a}\|_2^2 = \|\boldsymbol{b}\|_2^2 - \|\boldsymbol{b} - \boldsymbol{a}\|_2^2,$$

其中 $\boldsymbol{a} = \boldsymbol{y} - \boldsymbol{x}^+$，$\boldsymbol{b} = \boldsymbol{y} - \boldsymbol{z}$，得到

$$f(\boldsymbol{x}^+) - f(\boldsymbol{z}) \leq \frac{L}{2}\Big(\|\boldsymbol{y} - \boldsymbol{z}\|_2^2 - \|\boldsymbol{x}^+ - \boldsymbol{z}\|_2^2\Big). \tag{6.30}$$

第二步，选择比较点。省略上标 (t)，记 $\theta = \theta^{(t)}$，$\Delta_t = f(\boldsymbol{x}^{(t)}) - f^\star$。取

$$\boldsymbol{z} = \Big(1 - \frac{1}{\theta}\Big)\boldsymbol{x} + \frac{1}{\theta}\boldsymbol{x}^\star.$$

由凸性，

$$f(\boldsymbol{z}) - f^\star \leq \Big(1 - \frac{1}{\theta}\Big)\Delta_t.$$

代入式 (6.30)，两边乘以 θ^2，把 θ 乘进范数：

$$\theta^2\Delta_{t+1} - (\theta^2 - \theta)\Delta_t \leq \frac{L}{2}\Big(\|\theta\boldsymbol{y} - \theta\boldsymbol{z}\|_2^2 - \|\theta\boldsymbol{x}^+ - \theta\boldsymbol{z}\|_2^2\Big).$$

第三步，识别辅助点。令

$$\boldsymbol{v}^{(t)} = \theta^{(t)}\boldsymbol{y}^{(t)} - (\theta^{(t)} - 1)\boldsymbol{x}^{(t)},$$

于是

$$\theta\boldsymbol{y} - \theta\boldsymbol{z} = \boldsymbol{v}^{(t)} - \boldsymbol{x}^\star.$$

而由式 (6.21)和式 (6.28)，$\theta^{(t+1)}\boldsymbol{y}^{(t+1)}$ 可以写开，得到

$$\boldsymbol{v}^{(t+1)} = \boldsymbol{x}^{(t)} + \theta^{(t)}\big(\boldsymbol{x}^{(t+1)} - \boldsymbol{x}^{(t)}\big),$$

这恰好是 $\theta \boldsymbol{x}^{+} - \theta \boldsymbol{z} + \boldsymbol{x}^{\star}$。

第四步，定义势函数 $E^{(t)}$ 并裂项。规定 $\theta^{(-1)} = 0$，令

$$E^{(t)} = \left(\theta^{(t-1)}\right)^2 \Delta_t + \frac{L}{2}\|\boldsymbol{v}^{(t)} - \boldsymbol{x}^{\star}\|_2^2.$$

由 $\theta^2 - \theta = (\theta^{(t-1)})^2$（$t = 0$ 时两边都是零），上一步的不等式就是 $E^{(t+1)} \le E^{(t)}$。又 $\boldsymbol{v}^{(0)} = \boldsymbol{x}^{(0)}$，所以

$$\left(\theta^{(T-1)}\right)^2 \Delta_T \le E^{(T)} \le E^{(0)} = \frac{L}{2}\|\boldsymbol{x}^{(0)} - \boldsymbol{x}^{\star}\|_2^2.$$

再用 $\theta^{(T-1)} \ge (T+1)/2$，即得式 (6.29)。 ■

$1/T$ 变成了 $1/T^2$。目标差要达到 ε，步数从 $LR^2/(2\varepsilon)$ 降到约 $\sqrt{2L/\varepsilon}\,R$。图 6.12(a) 用一个三对角的二次函数验证这一点，它的特征值一路逼近零，强凸常数实际上帮不上忙。

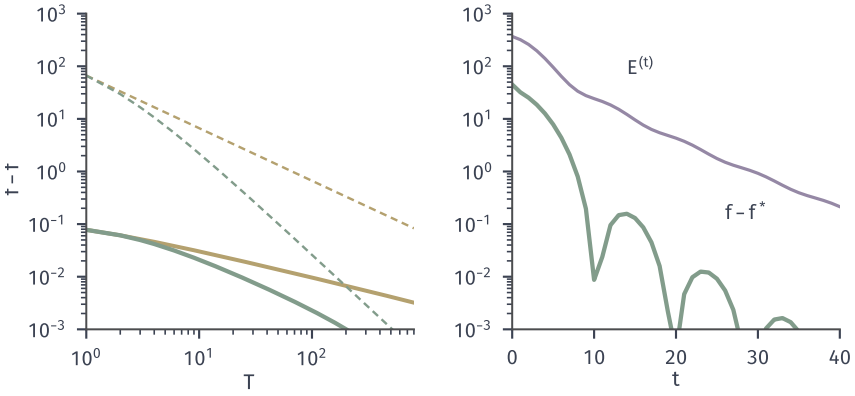


图 6.12　光滑凸目标上的 $1/T$ 与 $1/T^2$。(a) $f(\boldsymbol{x}) = \frac{1}{4}\left(\frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x} - x_1\right)$，$\boldsymbol{A}$ 是 400 阶三对角矩阵（对角元 2，次对角元 -1），$L = 1$，$\boldsymbol{x}^{(0)} = \boldsymbol{0}$。黄线是梯度下降，绿线是 Nesterov 方法（θ 形式），同色虚线是式 (6.9)、(6.29)的上界。(b) 贯穿例按 θ 形式运行，$L = 9$：绿线是目标差，出现回升；紫线是势函数 $E^{(t)}$，逐步下降。

图 6.12(b) 说明势函数的用意。贯穿例按式 (6.28)的参数运行时，$\beta^{(t)}$ 逐渐接近 1，动量过大，目标差出现 13 次回升，而 $E^{(t)}$ 从 369（$t = 0$）、320（$t = 1$）一路下降。凸情形的结论控制的是最后一步的目标差上界，并没有说目标差单调下降。

可以用势函数检查第一步的计算：由 $\theta^{(0)} = 1$ 得 $\boldsymbol{v}^{(1)} = \boldsymbol{x}^{(1)} = (8, 0)$，所以

$$E^{(1)} = 1 \cdot 32 + \frac{9}{2} \cdot 64 = 320, \qquad E^{(0)} = \frac{9}{2} \cdot 82 = 369.$$

6.1 梯度下降
6.2 动量与加速
6.3 非线性共轭梯度法
6.3.1 方向的更新
6.3.2 线搜索与重启
6.4 收敛与计算成本
6.5 本章小结

下表把两种动量方法放在一起对比。

表 6.2 重球法与 Nesterov 方法的对比。

	重球法	Nesterov 方法
梯度位置	当前点 $\boldsymbol{x}^{(t)}$	外推点 $\boldsymbol{y}^{(t)}$
动量对各方向	系数 β 相同	被 $1-\alpha\lambda$ 压低
α	$4/(\sqrt{L}+\sqrt{\mu})^2$	$1/L$
强凸时 β	$\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^2$	$\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$
二次目标的速度	$\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$	$1-1/\sqrt{\kappa}$
一般强凸光滑	这组参数可能不收敛	定理 6.6
光滑凸	本章不给结论	定理 6.7

适用范围 两条定理的证明都用切平面比较外推点与当前点、外推点与最优解，这正是凸性的作用。目标非凸时，切平面不再从下方托住目标，势函数的下降论证在第一步就不成立，这两条定理不能直接移用。非凸情形需要带函数值检查或重启的修改版本，另有专门的分析，得到的是驻点型的保证，本章不把上面的结论推广过去。

6.3 非线性共轭梯度法

上一节用历史位移修正步子，参数要事先知道 L，有时还要知道 μ。本节换一种用历史的方式：每轮保留上一轮的搜索方向，把它与新梯度组合成新方向，步长由线搜索决定，不需要预先知道曲率常数。要解决的问题是：怎样组合才合理，这样组合之后还能保证什么？

先回到正定二次目标

$$f(\boldsymbol{x})=\frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{H}\boldsymbol{x}-\boldsymbol{b}^{\top}\boldsymbol{x}.$$

这里已经有一个答案：共轭梯度法。它的梯度 $\boldsymbol{g}=\boldsymbol{H}\boldsymbol{x}-\boldsymbol{b}$ 就是残差的相反数，迭代为

$$\boldsymbol{d}^{(t)}=-\boldsymbol{g}^{(t)}+\beta^{(t)}\boldsymbol{d}^{(t-1)},\qquad \beta^{(t)}=\frac{\|\boldsymbol{g}^{(t)}\|_2^2}{\|\boldsymbol{g}^{(t-1)}\|_2^2},$$

步长是沿 $\boldsymbol{d}^{(t)}$ 的精确最小点。各方向两两关于 $\boldsymbol{H}$ 共轭，精确算术下至多 n 步得到解。这些结论的推导可参考卷二第 15 章“Krylov 子空间法”。

共轭的意思是 $(\boldsymbol{d}^{(i)})^{\top}\boldsymbol{H}\boldsymbol{d}^{(j)}=0$。用椭圆的语言说：把椭圆拉成圆后，这些方向互相垂直，所以沿一个方向走到位之后，后面的方向不会破坏已经

6.1 梯度下降
6.2 动量与加速
6.3 非线性共轭梯度法
6.3.1 方向的更新
6.3.2 线搜索与重启
6.4 收敛与计算成本
6.5 本章小结

完成的进度。图 6.13是贯穿例上的情形：最速下降在折返，共轭梯度第二步直接指向中心。

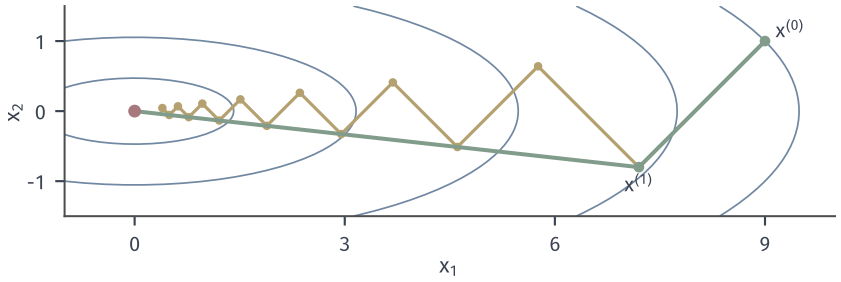


图 6.13　贯穿例上的精确线搜索路径，蓝色椭圆是等高线。黄色路径是最速下降，绿色路径是共轭梯度法。两者第一步相同，都到达 $\boldsymbol{x}^{(1)} = (7.2, -0.8)$；共轭梯度的第二步到达最优解（红点），最速下降则继续折返。

目标不是二次时，两个前提都不存在：没有固定的 $\boldsymbol{H}$，共轭的定义失去了依托；一般也求不出沿线的精确最小点。**非线性共轭梯度法**（nonlinear conjugate gradient method）只保留方向递推的形式，用真实的梯度代替残差，用线搜索代替精确步长。代价是，共轭性一般不再精确保持，有限步终止的结论也不再成立。

6.3.1 方向的更新

主要思想　方法的骨架是

$$\boldsymbol{d}^{(t)} = -\boldsymbol{g}^{(t)} + \beta^{(t)} \boldsymbol{d}^{(t-1)}, \qquad \boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} + \alpha^{(t)} \boldsymbol{d}^{(t)}, \tag{6.31}$$

其中 $\boldsymbol{d}^{(0)} = -\boldsymbol{g}^{(0)}$。它只比梯度下降多存一个向量。需要决定的只有两件事：$\beta^{(t)}$ 怎样算，$\alpha^{(t)}$ 怎样选。这一小节讨论前者。

在二次目标上，$\beta^{(t)}$ 可以写成好几种形式，它们彼此相等。写法不同，推广到非线性时就成了不同的算法。从共轭条件出发，要求 $(\boldsymbol{d}^{(t)})^{\top} \boldsymbol{H} \boldsymbol{d}^{(t-1)} = 0$，由式 (6.31)得

$$\beta^{(t)} = \frac{(\boldsymbol{g}^{(t)})^{\top} \boldsymbol{H} \boldsymbol{d}^{(t-1)}}{(\boldsymbol{d}^{(t-1)})^{\top} \boldsymbol{H} \boldsymbol{d}^{(t-1)}}.$$

式中含有 $\boldsymbol{H}$，非线性时无法直接使用。在二次目标上，相邻梯度之差恰好是 $\boldsymbol{H}$ 作用在位移上：

$$\boldsymbol{\delta}^{(t)} := \boldsymbol{g}^{(t)} - \boldsymbol{g}^{(t-1)} = \alpha^{(t-1)} \boldsymbol{H} \boldsymbol{d}^{(t-1)}.$$

把它代入上式，消去 $\alpha^{(t-1)}$，得到只含梯度和方向的表达式：

$$\beta^{(t)} = \frac{(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{\delta}^{(t)}}{(\boldsymbol{d}^{(t-1)})^{\top}\boldsymbol{\delta}^{(t)}}.$$

精确线搜索使 $(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}^{(t-1)} = 0$，并且同样有 $(\boldsymbol{g}^{(t-1)})^{\top}\boldsymbol{d}^{(t-2)} = 0$，由式 (6.31)得

$$(\boldsymbol{d}^{(t-1)})^{\top}\boldsymbol{\delta}^{(t)} = -(\boldsymbol{d}^{(t-1)})^{\top}\boldsymbol{g}^{(t-1)} = \|\boldsymbol{g}^{(t-1)}\|_2^2.$$

这样分母化成了 $\|\boldsymbol{g}^{(t-1)}\|_2^2$，得到Polak–Ribière–Polyak 公式（Polak–Ribière–Polyak formula，PRP）：

$$\beta_{\mathrm{PRP}}^{(t)} = \frac{(\boldsymbol{g}^{(t)})^{\top}\big(\boldsymbol{g}^{(t)} - \boldsymbol{g}^{(t-1)}\big)}{\|\boldsymbol{g}^{(t-1)}\|_2^2}. \tag{6.32}$$

再用线性共轭梯度中相邻梯度的正交性 $(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{g}^{(t-1)} = 0$，分子只剩 $\|\boldsymbol{g}^{(t)}\|_2^2$，得到Fletcher–Reeves 公式（Fletcher–Reeves formula，FR）：

$$\beta_{\mathrm{FR}}^{(t)} = \frac{\|\boldsymbol{g}^{(t)}\|_2^2}{\|\boldsymbol{g}^{(t-1)}\|_2^2}. \tag{6.33}$$

两个公式利用的信息不同。FR 只看两个梯度的长度，恒为正；PRP 还看梯度变化 $\boldsymbol{\delta}^{(t)}$，它含有两点之间的曲率信息，符号可正可负。在正定二次目标加精确线搜索时两者一致，离开这个条件就是两个算法，下降性和收敛性要分别讨论。

变量

- $\boldsymbol{x}^{(t)} \in \mathbb{R}^n$：当前点。
- $\boldsymbol{g}^{(t)}, \boldsymbol{g}^{(t-1)} \in \mathbb{R}^n$：当前与上一轮的梯度，FR 只需要它们的长度平方，PRP 需要向量。
- $\boldsymbol{d}^{(t)} \in \mathbb{R}^n$：搜索方向，算出新方向后覆盖。
- $\alpha^{(t)}$，$\beta^{(t)}$：步长与组合系数，用后即弃。
- ε，T：容差与最大步数。

初始化　令 $\boldsymbol{g}^{(0)} = \nabla f(\boldsymbol{x}^{(0)})$，$\boldsymbol{d}^{(0)} = -\boldsymbol{g}^{(0)}$，$t = 0$。例中

$$\boldsymbol{g}^{(0)} = (9, 9), \qquad \boldsymbol{d}^{(0)} = (-9, -9), \qquad \|\boldsymbol{g}^{(0)}\|_2^2 = 162.$$

每轮更新 在第 t 轮：

1. **线搜索**。沿 $\boldsymbol{d}^{(t)}$ 确定步长 $\alpha^{(t)}$。这里先用精确步长，下一小节讨论实际的规则。二次目标的精确步长是

$$\alpha^{(t)} = -\frac{(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}^{(t)}}{(\boldsymbol{d}^{(t)})^{\top}\boldsymbol{H}\boldsymbol{d}^{(t)}}.$$

   例中第一轮

$$\alpha^{(0)} = \frac{162}{(-9)^2\cdot 1 + (-9)^2\cdot 9} = \frac{162}{810} = \frac{1}{5}.$$

2. **更新点并读取新梯度**。由式 (6.31)得到 $\boldsymbol{x}^{(t+1)}$，并计算 $\boldsymbol{g}^{(t+1)}$。例中第一轮

$$\boldsymbol{x}^{(1)} = (7.2, -0.8), \qquad \boldsymbol{g}^{(1)} = (7.2, -7.2).$$

3. **检查停止**。若 $\|\boldsymbol{g}^{(t+1)}\|_2 \le \varepsilon$ 或已达 T 步，输出 $\boldsymbol{x}^{(t+1)}$。例中第一轮 $\|\boldsymbol{g}^{(1)}\|_2^2 = 103.68$，继续。

4. **计算系数并更新方向**。按式 (6.33)或式 (6.32)算 $\beta^{(t+1)}$，再由式 (6.31)算 $\boldsymbol{d}^{(t+1)}$，令 $t \leftarrow t+1$。例中第一轮，$(\boldsymbol{g}^{(1)})^{\top}\boldsymbol{g}^{(0)} = 0$，所以两个公式给出同一值：

$$\beta^{(1)} = \frac{103.68}{162} = 0.64.$$

   新方向是

$$\boldsymbol{d}^{(1)} = (-7.2, 7.2) + 0.64(-9, -9) = (-12.96,\ 1.44).$$

   可以核对共轭关系：

$$(\boldsymbol{d}^{(1)})^{\top}\boldsymbol{H}\boldsymbol{d}^{(0)} = 116.64 - 116.64 = 0.$$

   例中第二轮线搜索，方向导数和曲率分别是

$$-(\boldsymbol{g}^{(1)})^{\top}\boldsymbol{d}^{(1)} = 103.68, \qquad (\boldsymbol{d}^{(1)})^{\top}\boldsymbol{H}\boldsymbol{d}^{(1)} = 186.624,$$

   于是

$$\alpha^{(1)} = \frac{103.68}{186.624} = \frac{5}{9}, \qquad \boldsymbol{x}^{(2)} = (7.2, -0.8) + \tfrac{5}{9}(-12.96, 1.44) = (0, 0).$$

   此时 $\boldsymbol{g}^{(2)} = \boldsymbol{0}$，满足停止条件。

最终得到 $\boldsymbol{x}^{(2)} = \boldsymbol{x}^{\star}$。二维的二次目标两步到达，这与 n 步终止的结论相符。图 6.14画出第二轮方向的合成：新梯度方向 $-\boldsymbol{g}^{(1)}$ 与上一方向 $\boldsymbol{d}^{(0)}$ 按平行四边形相加，结果恰好指向椭圆中心。

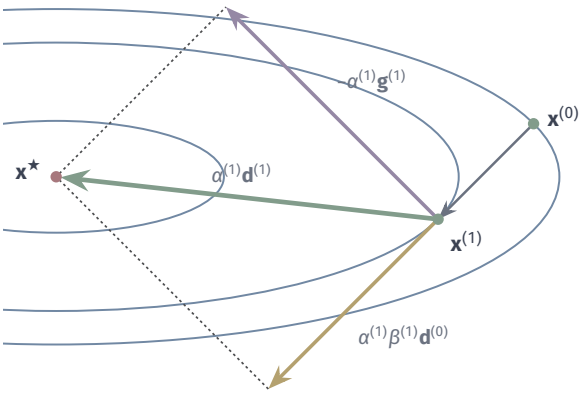


图 6.14 贯穿例第二轮的方向合成，蓝色椭圆是等高线。紫色箭头是负梯度 $-\boldsymbol{g}^{(1)}$，黄色箭头是上一方向 $\boldsymbol{d}^{(0)}$ 乘以 $\beta^{(1)} = 0.64$，两者都按步长 $\alpha^{(1)} = 5/9$ 缩放。绿色箭头是它们的和，从 $\boldsymbol{x}^{(1)}$ 直达最优解（红点）。

两个公式何时不同 精确线搜索一旦放宽，即使目标还是二次的，两个公式也立刻分开。在贯穿例第一轮取 $\alpha^{(0)} = 1/9$，它满足下一小节将列出的线搜索条件，于是

$$\boldsymbol{x}^{(1)} = (8, 0), \qquad \boldsymbol{g}^{(1)} = (8, 0), \qquad (\boldsymbol{g}^{(1)})^{\top}\boldsymbol{g}^{(0)} = 72.$$

这时相邻梯度不再正交。两个系数分别是

$$\beta^{(1)}_{\mathrm{FR}} = \frac{64}{162} \approx 0.395, \qquad \beta^{(1)}_{\mathrm{PRP}} = \frac{64 - 72}{162} \approx -0.049.$$

PRP 的系数是负的，符号都不同了。对应的方向是

$$\boldsymbol{d}^{(1)}_{\mathrm{FR}} \approx (-11.56, -3.56), \qquad \boldsymbol{d}^{(1)}_{\mathrm{PRP}} \approx (-7.56, 0.44).$$

两者都不再与 $\boldsymbol{d}^{(0)}$ 共轭，例如

$$(\boldsymbol{d}^{(1)}_{\mathrm{FR}})^{\top}\boldsymbol{H}\boldsymbol{d}^{(0)} = 392 \neq 0.$$

方程的形式相同，并不意味着结论相同。

目标非二次时，共轭性的流失更彻底。把贯穿例弯曲一下，取

$$f(\boldsymbol{x}) = \frac{1}{2}x_1^2 + \frac{9}{2}\bigl(x_2 - 0.1x_1^2\bigr)^2. \tag{6.34}$$

这是一条沿抛物线弯曲的山谷，$\boldsymbol{x}^\star = \boldsymbol{0}$ 处的 Hessian 仍是 $\mathrm{diag}(1, 9)$，系数 0.1 换成零就回到式 (6.1)。

图 6.15(b) 用近乎精确的线搜索运行 PRP，并计算相邻方向在当前 Hessian 下的共轭余弦。它在开始时接近 0.8，远不是零；直到迭代进入极小

6.1 梯度下降
6.2 动量与加速
6.3 非线性共轭梯度法
6.3.1 方向的更新
6.3.2 线搜索与重启
6.4 收敛与计算成本
6.5 本章小结

点附近、目标接近二次，这个量才逐渐变小。这个二维问题走了 9 步才把梯度降到 10^{-6} 以下，n 步终止不再成立。

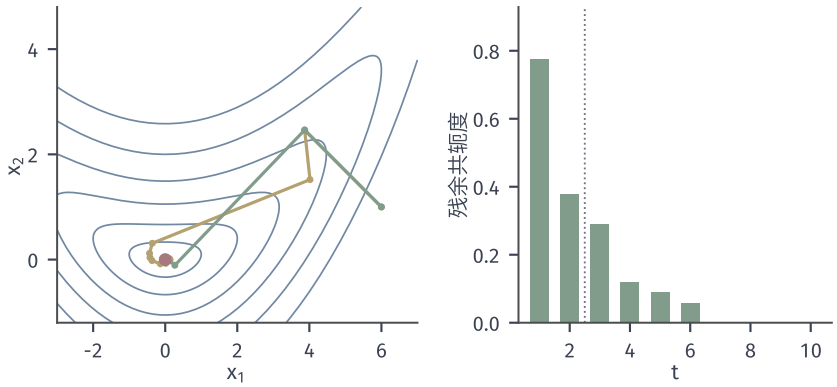


图 6.15　弯谷目标 (6.34)上的非线性共轭梯度法，起点 $(6,1)$。(a) 黄线 FR，绿线是把负的 PRP 系数截断为零的变体 PRP+，都采用强 Wolfe 线搜索（$c_1 = 10^{-4}$，$c_2 = 0.4$），画出前 17 步。(b) 近似精确线搜索下的 PRP，相邻方向的残余共轭度 $|(\boldsymbol{d}^{(t)})^{\top}\nabla^2 f\,\boldsymbol{d}^{(t-1)}|$ 除以两方向的 $\nabla^2 f$ 长度之积，Hessian 取在 $\boldsymbol{x}^{(t)}$；虚线之前是二次目标应该结束的步数。

6.3.2 线搜索与重启

强 Wolfe 条件　实际中一般不求沿线精确的最小点。第 5章的强 Wolfe 条件要求步长 α 既满足 Armijo 条件 (6.5)，又让方向导数的绝对值变小：

$$\left|\nabla f(\boldsymbol{x}+\alpha\boldsymbol{d})^{\top}\boldsymbol{d}\right| \le c_2\left|\nabla f(\boldsymbol{x})^{\top}\boldsymbol{d}\right|, \qquad 0 < c_1 < c_2 < 1. \tag{6.35}$$

前一个条件防止走得太远，后一个条件防止走得太近，同时把新点放到沿线函数接近平坦的位置。

贯穿例沿 $\boldsymbol{d}^{(0)} = (-9,-9)$ 的一维函数是 $\varphi(\alpha) = 45 - 162\alpha + 405\alpha^2$，方向导数为 $\varphi'(\alpha) = -162 + 810\alpha$。取 $c_1 = 0.1$，$c_2 = 0.45$，Armijo 条件给出 $\alpha \le 0.36$，强 Wolfe 条件给出

$$0.11 \le \alpha \le 0.29.$$

图 6.16中，$\alpha = 1/9$ 落在区间内，精确步长 $1/5$ 也在区间内。

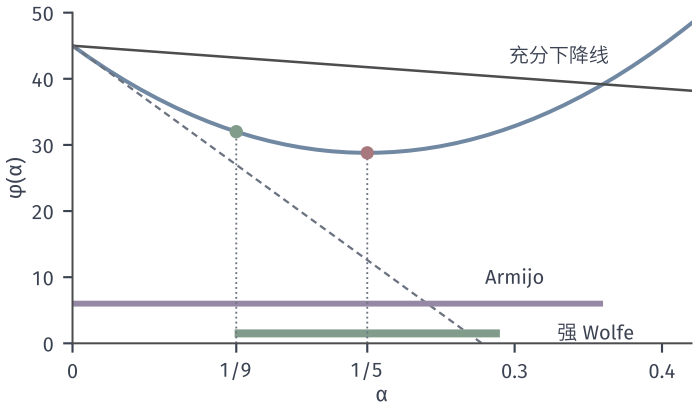


图 6.16 线搜索的可接受区间。蓝色曲线是贯穿例沿 $\boldsymbol{d}^{(0)}$ 的 $\varphi(\alpha)$，黑色实线是 $c_1 = 0.1$ 的充分下降线，虚线是 φ 在 0 处的切线。紫色线段是 Armijo 条件接受的区间，绿色线段是再加上 $c_2 = 0.45$ 的强 Wolfe 区间。绿点是 $\alpha = 1/9$，红点是精确最小点 $\alpha = 1/5$。

FR 的下降保证 方向必须是下降方向，线搜索才有意义。梯度下降中这是自动的，这里却不一定：$(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}^{(t)}$ 等于 $-\|\boldsymbol{g}^{(t)}\|_2^2$ 加上 $\beta^{(t)}(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}^{(t-1)}$，后一项可以是正的。精确线搜索让后一项为零；不精确时，强 Wolfe 条件要限制它的大小。对 FR，这需要把 c_2 压到 $\frac{1}{2}$ 以下。

引理 6.8 FR 方向的下降性 设 f 连续可微，每步按强 Wolfe 条件取 $\alpha^{(t)}$，$0 < c_1 < c_2 < \frac{1}{2}$，$\beta^{(t)}$ 取式 (6.33)，且 $\boldsymbol{g}^{(t)} \neq \boldsymbol{0}$。则对所有 t，

$$-\frac{1}{1-c_2} \le \frac{(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}^{(t)}}{\|\boldsymbol{g}^{(t)}\|_2^2} \le \frac{2c_2-1}{1-c_2} < 0. \tag{6.36}$$

证明 记中间的比值为 $\tau^{(t)}$。对 t 归纳。$t = 0$ 时 $\tau^{(0)} = -1$，而

$$-\frac{1}{1-c_2} \le -1 \le \frac{2c_2-1}{1-c_2},$$

后一个不等号等价于 $c_2 \ge 0$。

设结论对 t 成立，特别地 $\boldsymbol{d}^{(t)}$ 是下降方向，线搜索可以进行。由式 (6.31)和 $\beta_{\mathrm{FR}}^{(t+1)}$ 的定义，

$$\tau^{(t+1)} = -1 + \frac{(\boldsymbol{g}^{(t+1)})^{\top}\boldsymbol{d}^{(t)}}{\|\boldsymbol{g}^{(t)}\|_2^2}.$$

强 Wolfe 条件 (6.35)给出

$$\left|(\boldsymbol{g}^{(t+1)})^{\top}\boldsymbol{d}^{(t)}\right| \le -c_2(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}^{(t)}.$$

除以 $\|\boldsymbol{g}^{(t)}\|_2^2$，得到

$$-1 + c_2\tau^{(t)} \le \tau^{(t+1)} \le -1 - c_2\tau^{(t)}.$$

代入归纳假设的下界 $\tau^{(t)} \ge -1/(1-c_2)$，左端不小于 $-1/(1-c_2)$，右端不大于 $(2c_2-1)/(1-c_2)$。由 $c_2 < \frac{1}{2}$，右端为负。 ■

用上面 $\alpha^{(0)} = 1/9$ 的数据检验。$c_2 = 0.45$ 时 $\alpha^{(0)}$ 可接受，引理的区间是 $[-1.82, -0.18]$，而

$$\tau^{(1)} = \frac{(8,0)^{\top}(-11.56,-3.56)}{64} \approx -1.44,$$

确实落在区间内。

FR 的全局收敛 下降方向还不够，还要防止方向几乎与梯度垂直。记 $\theta^{(t)}$ 为 $\boldsymbol{d}^{(t)}$ 与 $-\boldsymbol{g}^{(t)}$ 的夹角。Wolfe 条件带来一个累加估计，它把线搜索的效果转化为对夹角的约束。

引理 6.9 Zoutendijk 条件 设 f 有下界，梯度 L-Lipschitz 连续，$\boldsymbol{d}^{(t)}$ 都是下降方向，步长满足 Armijo 条件和 Wolfe 曲率条件（方向导数至少升到原值的 c_2 倍，$0 < c_1 < c_2 < 1$）。则

$$\sum_{t=0}^{\infty} \cos^2\theta^{(t)}\|\boldsymbol{g}^{(t)}\|_2^2 < \infty. \tag{6.37}$$

证明 曲率条件是

$$(\boldsymbol{g}^{(t+1)})^{\top}\boldsymbol{d}^{(t)} \ge c_2(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}^{(t)}.$$

两边减去 $(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}^{(t)}$，得到

$$(\boldsymbol{g}^{(t+1)} - \boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}^{(t)} \ge (c_2 - 1)(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}^{(t)}.$$

由梯度 Lipschitz，左端不超过 $\alpha^{(t)} L\|\boldsymbol{d}^{(t)}\|_2^2$。于是步长有下界

$$\alpha^{(t)} \geq \frac{(1-c_2)|(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}^{(t)}|}{L\|\boldsymbol{d}^{(t)}\|_2^2}.$$

代入 Armijo 条件，并用 $|\boldsymbol{g}^{\top}\boldsymbol{d}|$ 与 $\cos\theta$ 的关系，得到

$$f(\boldsymbol{x}^{(t)}) - f(\boldsymbol{x}^{(t+1)}) \geq \frac{c_1(1-c_2)}{L}\cos^2\theta^{(t)}\|\boldsymbol{g}^{(t)}\|_2^2.$$

对 t 求和，函数值裂项，再用下界，即得结论。 ■

定理 6.10　FR 与强 Wolfe 线搜索　设 f 有下界，梯度 L-Lipschitz 连续。按 FR 公式迭代，步长满足强 Wolfe 条件，$0 < c_1 < c_2 < \frac{1}{2}$。若每步 $\boldsymbol{g}^{(t)} \neq \boldsymbol{0}$，则

$$\liminf_{t\to\infty} \|\boldsymbol{g}^{(t)}\|_2 = 0. \tag{6.38}$$

证明　用反证法。设存在 $\gamma > 0$ 使 $\|\boldsymbol{g}^{(t)}\|_2 \geq \gamma$ 对所有 t 成立。先估计方向的长度。由引理 6.8，

$$\left|(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}^{(t)}\right| \leq \frac{\|\boldsymbol{g}^{(t)}\|_2^2}{1-c_2}.$$

再由强 Wolfe 条件，并用 FR 公式把 $\beta^{(t+1)}\|\boldsymbol{g}^{(t)}\|_2^2$ 换成 $\|\boldsymbol{g}^{(t+1)}\|_2^2$，展开 $\|\boldsymbol{d}^{(t+1)}\|_2^2$，得到

$$\|\boldsymbol{d}^{(t+1)}\|_2^2 \leq \frac{1+c_2}{1-c_2}\|\boldsymbol{g}^{(t+1)}\|_2^2 + \left(\beta^{(t+1)}\right)^2\|\boldsymbol{d}^{(t)}\|_2^2.$$

记 $c = (1+c_2)/(1-c_2) \geq 1$。两边除以 $\|\boldsymbol{g}^{(t+1)}\|_2^4$，由 FR 公式消去 $\beta^{(t+1)}$，因此

$$\frac{\|\boldsymbol{d}^{(t+1)}\|_2^2}{\|\boldsymbol{g}^{(t+1)}\|_2^4} \leq \frac{\|\boldsymbol{d}^{(t)}\|_2^2}{\|\boldsymbol{g}^{(t)}\|_2^4} + \frac{c}{\|\boldsymbol{g}^{(t+1)}\|_2^2}.$$

由 $\boldsymbol{d}^{(0)} = -\boldsymbol{g}^{(0)}$，归纳可得

$$\frac{\|\boldsymbol{d}^{(t)}\|_2^2}{\|\boldsymbol{g}^{(t)}\|_2^4} \leq \frac{c(t+1)}{\gamma^2}.$$

再由引理 6.8的上界，

$$|\boldsymbol{g}^{\top}\boldsymbol{d}| \geq c'\|\boldsymbol{g}\|_2^2, \qquad c' = \frac{1-2c_2}{1-c_2} > 0.$$

所以

$$\cos^2\theta^{(t)}\|\boldsymbol{g}^{(t)}\|_2^2 = \frac{(\boldsymbol{g}^{\top}\boldsymbol{d})^2}{\|\boldsymbol{d}\|_2^2} \geq \frac{c'^2\|\boldsymbol{g}\|_2^4}{\|\boldsymbol{d}\|_2^2} \geq \frac{c'^2\gamma^2}{c(t+1)}.$$

右端对 t 求和发散，与式 (6.37)矛盾。 ■

定理不要求凸，结论是驻点型的，而且只是 lim inf，说明有一列子序列的梯度趋于零。它与定理 6.2的 $\|\boldsymbol{g}^{(t)}\|_2 \to 0$ 相比更弱，也不给出步数的界。

条件 $c_2 < \frac{1}{2}$ 在这里是起作用的：引理的证明里，它让上界保持为负。一旦 $c_2 \geq \frac{1}{2}$，上述论证不能保证方向下降。

FR 的卡顿与 PRP 的自动重启 定理保证了极限，却不保证速度。FR 有一种典型的卡顿现象。若某一步步长很小，$\boldsymbol{g}^{(t)} \approx \boldsymbol{g}^{(t-1)}$，那么 $\beta_{\mathrm{FR}}^{(t)} \approx 1$，新方向约为 $-\boldsymbol{g}^{(t)} + \boldsymbol{d}^{(t-1)}$，几乎沿用了旧方向。旧方向已经效果不佳，下一步又只能走很小的一步，如此延续。

PRP 在同样的情形下，分子含有接近零的差 $\boldsymbol{g}^{(t)} - \boldsymbol{g}^{(t-1)}$，于是 $\beta_{\mathrm{PRP}}^{(t)} \approx 0$，方向自动回到负梯度，相当于重新开始。这就是实践中 PRP 一般比 FR 好的原因。图 6.17在弯谷上对比了它们。

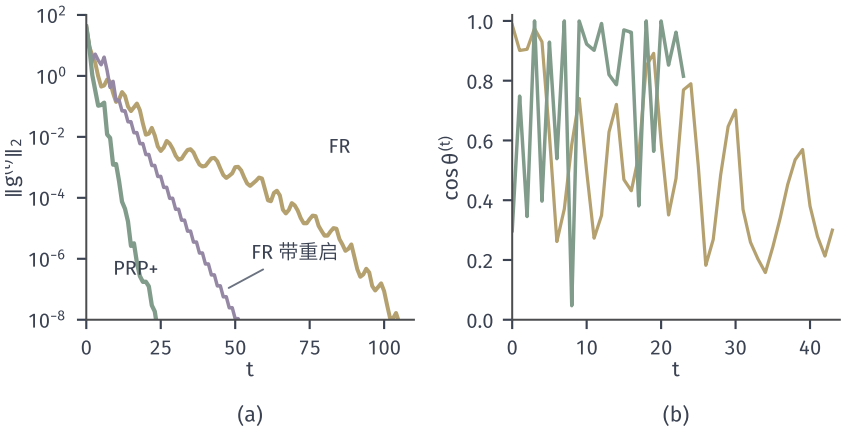


图 6.17 弯谷目标 (6.34)上的三种方案，起点 $(6,1)$，强 Wolfe 线搜索 $c_1 = 10^{-4}$，$c_2 = 0.4$。(a) 梯度大小：黄线是 FR，紫线是 FR 加 Powell 重启（式 (6.41)，$\nu = 0.1$），绿线是 PRP+。(b)$\boldsymbol{d}^{(t)}$ 与 $-\boldsymbol{g}^{(t)}$ 的夹角余弦：黄线 FR 在后期长时间偏低，绿线 PRP+ 能够多次回到接近 1 的位置。

PRP+ 的下降保障 PRP 的优点有代价。Powell 构造过非凸的例子，PRP 配合精确线搜索也可能在一组非驻点之间循环，这说明全局收敛不能指望公式本身。这样的反例需要专门构造，证明的细节读者可查阅[3]。

[3] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

一个常用的修改是把负的系数截断为零：

$$\beta_{\mathrm{PRP}+}^{(t)} = \max\{\beta_{\mathrm{PRP}}^{(t)}, 0\}. \tag{6.39}$$

其含义是：若梯度变化表明上一方向已不再有帮助，就直接扔掉它。贯穿例上 $\alpha^{(0)} = 1/9$ 的那一步，PRP+ 的 β 就是 0，新方向是负梯度 $(-8, 0)$。

只截断还不够。与 FR 不同，PRP+ 在强 Wolfe 条件下并不自动产生下降方向，因为 β 的大小不再受 $\|\boldsymbol{g}^{(t)}\|_2^2/\|\boldsymbol{g}^{(t-1)}\|_2^2$ 限制。已知的收敛定理要求额外的条件：f 的下水平集有界，梯度 Lipschitz，线搜索除强 Wolfe 条件之外还要保证充分下降，即存在 $c > 0$ 使

$$(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}^{(t)} \le -c\|\boldsymbol{g}^{(t)}\|_2^2. \tag{6.40}$$

在这些条件下可以得到 $\liminf \|\boldsymbol{g}^{(t)}\|_2 = 0$。证明要追踪归一化方向的变化量并作累计估计，篇幅较长，读者可查阅[4]。这个结论本章没有证明，它依赖的是“PRP+、线搜索与充分下降”三者的组合，缺一项就不能引用。

[4] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

重启 非线性情形下，旧方向携带的曲率信息随着地形变化而过期。**重启**（restart）就是把方向重置为负梯度，丢弃旧方向。常用的触发条件有三种。

第一种检测方向不再下降：若新方向不满足式 (6.40)，立即令 $\boldsymbol{d}^{(t)} = -\boldsymbol{g}^{(t)}$。第二种按周期：每 n 步重启一次，相当于让方向序列按段重新建立。第三种由 Powell 提出，检测相邻梯度偏离了线性共轭梯度中的正交性：若

$$\left|(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{g}^{(t-1)}\right| \ge \nu\|\boldsymbol{g}^{(t)}\|_2^2, \qquad \nu \approx 0.1, \tag{6.41}$$

就重启。

重启并不总是有益的。图 6.17(a) 的数据是：从 $(6, 1)$ 出发，目标梯度 10^{-8}，FR 走了 105 步，加上重启后降到 52 步，PRP+ 只要 24 步。而对 PRP+ 再加上式 (6.41)，在贯穿起点 $(9, 1)$ 上反而从 28 步增加到 52 步，因为 PRP+ 本身已经在需要时自动重置，额外的重启浪费了仍然有用的方向。

下表把变体、线搜索和保证的组合列在一起。引用某个结论时，三列必须同时对应。

6.1 梯度下降
6.2 动量与加速
6.3 非线性共轭梯度法
6.4 收敛与计算成本
6.5 本章小结

表 6.3 非线性共轭梯度的常见组合，表中收敛都是 $\liminf \|\boldsymbol{g}^{(t)}\|_2 = 0$。

变体	线搜索与附加条件	下降性与收敛
FR	强 Wolfe，$c_2 < \frac{1}{2}$	下降，定理 6.10
PRP	精确或强 Wolfe	可能循环，无一般保证
PRP+	强 Wolfe，式 (6.40)	收敛，本章未证
加重启	依所用变体	保证随所用规则核对

6.4 收敛与计算成本

前三节各自给出了保证和例子。于是要问：要在几种方法中选择时，应该按什么标准比较？按第 5章的约定，比较时要固定三件事：度量误差的量、停止精度和要报告的迭代点，然后计算达到这一精度所需的总计算。

同样的尺子 贯穿例上，以梯度大小不超过 10^{-3} 为停止标准，各方法的结果如下表。固定步长的方法每步读一次梯度，读取次数与步数大体相等。

表 6.4 贯穿例上达到 $\|\boldsymbol{g}\|_2 \le 10^{-3}$ 的步数。

方法	参数	步数
梯度下降	$\alpha = 1/9$	78
梯度下降	$\alpha = 1/5$	43
重球法	$\alpha = \beta = 1/4$	19
Nesterov 方法	$\alpha = 1/9$，$\beta = 1/2$	29
共轭梯度	精确线搜索	2

这张表不能拿来宣布胜负。共轭梯度的 2 步依赖于目标是二次的，而且精确步长用到了 $\boldsymbol{H}$；重球法的 19 步依赖于事先知道 μ 和 L，并且只对二次目标有理论保证；三种固定步长的方法都不必做线搜索。下面把这些差异分别计入。

保证的比较 下表汇总本章的保证，$R = \|\boldsymbol{x}^{(0)} - \boldsymbol{x}^\star\|_2$，$\Delta = f(\boldsymbol{x}^{(0)}) - f_{\inf}$。不同列的度量不同：非凸列是梯度大小，凸与强凸列是目标差。

表 6.5 各方法的理论保证，$\Phi^{(0)} = f(\boldsymbol{x}^{(0)}) - f^\star + \frac{\mu}{2}R^2$，“—”表示本章不给结论。

方法	非凸	凸	强凸
梯度下降	$\min\|\boldsymbol{g}\|_2^2 \le \frac{2L\Delta}{T}$	$\frac{LR^2}{2T}$	$(1-\frac{1}{\kappa})^T\Delta$
重球法	—	—	二次目标 $(2T+1)\rho^T$
Nesterov 方法	—	$\frac{2LR^2}{(T+1)^2}$	$(1-\frac{1}{\sqrt{\kappa}})^T\Phi^{(0)}$
FR	$\liminf\|\boldsymbol{g}\|_2 = 0$	同左	同左

重球法一行的界是解距离的比例，$\rho = (\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$。FR 的“同左”表示在凸和强凸情形下，本章的定理仍然只给出驻点型的结论。这与实际的快慢不是一回事：FR 在实践中常比梯度下降快，但本章的定理没有给出这一点。

T 与 κ 的影响可以换算成具体的数字。取 $\kappa = 10^4$，目标差要降到初值的 10^{-6}，$\ln 10^6 \approx 13.8$，于是

$$\kappa \ln\frac{1}{\varepsilon} \approx 1.38\times 10^5, \qquad \sqrt{\kappa}\ln\frac{1}{\varepsilon} \approx 1.38\times 10^3.$$

相差一百倍。这是梯度下降与加速方法在定理的上界上的差别。Nesterov 方法的 $\sqrt{\kappa}$ 和 $1/T^2$ 依赖，在“新迭代点只在已读取梯度的张成空间内”这类方法中不能进一步改进；证明需要构造一个三对角的二次函数，让前 T 步的梯度只能探到前 T 个坐标，篇幅较长，读者可查阅凸优化的专门著作。图 6.12所用的函数正是这种构造。

一步要花多少 迭代次数只是总计算的一个因子。每步的代价由三部分构成：梯度读取、线搜索的函数试探、向量的更新与存储。

表 6.6 每步的代价，维数为 n。

方法	梯度读取	存储向量	需要的信息
梯度下降（固定）	1	2	L
梯度下降（回溯）	1 加试探	2	无
重球法	1	3	L, μ
Nesterov 方法	1	3	L，强凸时加 μ
非线性共轭梯度	多次	3 到 4	无

向量更新都是 $O(n)$，与读一次梯度相比通常可以忽略。除非目标是高度结构化的，读一次梯度的代价要大得多。所以比较的主要量是梯度与函数的读取次数，而不是迭代步数。

强 Wolfe 线搜索每步要在试探点上计算函数值和方向导数，后者需要整个梯度，一次试探大约相当于一次完整的梯度读取。试探次数取决于初始步长的猜测和 c_2 的松紧。例如弯谷上 $c_2 = 0.4$ 时，PRP+ 走了 24 步，用了 75 次读取，平均每步约 3 次。

步数少不等于计算少 图 6.18在一个 100 维的问题上比较四种方法：

$$f(\boldsymbol{x}) = \frac{1}{2}\sum_{i=1}^{100} \lambda_i x_i^2 + \sum_{i=1}^{100} \ln\cosh x_i,$$

其中 λ_i 在 $[1, 1000]$ 内按对数等距分布。目标强凸，$\mu = 1$，$L = 1001$，要求 $\|\boldsymbol{g}\|_2 \le 10^{-6}$。

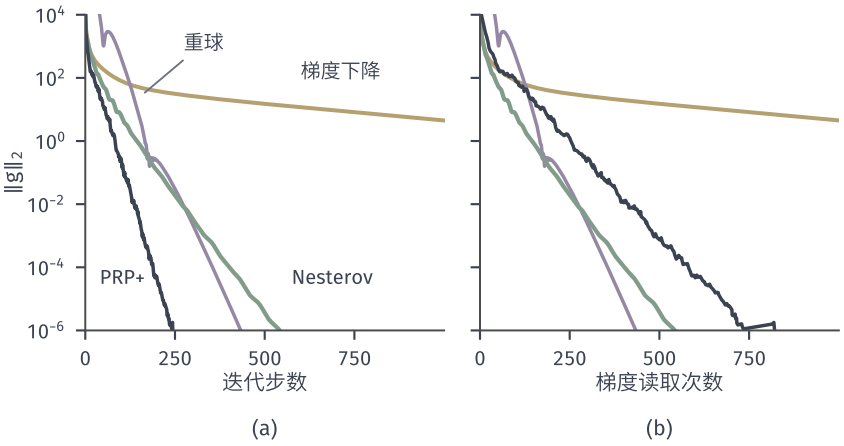


图 6.18 100 维强凸非二次目标上的梯度大小，$\kappa = 1001$，起点由固定种子的正态随机数给出。黄线是 $\alpha = 1/L$ 的梯度下降，紫线是按式 (6.16)取参数的重球法，绿线是强凸参数的 Nesterov 方法，黑线是 PRP+ 配合强 Wolfe 线搜索（$c_1 = 10^{-4}$，$c_2 = 0.1$）。(a) 横轴是迭代步数。(b) 横轴是梯度读取次数，同一组数据的位置变了。

按迭代步数，PRP+ 最少，244 步，重球法 434 步，Nesterov 方法 542 步，梯度下降 7574 步。按梯度读取，PRP+ 用了 821 次，比重球法的 435 次和 Nesterov 方法的 543 次都多。只看左图会选 PRP+，只看右图会选重球法。

这张图也提醒另一点。重球法在这里表现好，但定理不保证它：目标不是二次的。Nesterov 方法多读了约百分之二十五的梯度，换来的是对这一类目标有定理保证。四种配置中只有 PRP+ 不需要 L 和 μ。这两个常数无法估计时，它可以直接运行；梯度下降配回溯也能做到这一点，只是更慢。

输出什么 最后要说明报告哪个点。按定理 6.2的说法，非凸时应记录梯度最小的迭代点；凸与强凸的定理针对最后一个迭代点。Nesterov 方法的目标差不单调，如果需要，可以另外保留函数值最低的点，这只需要在已经计算函数值时比较。

6.1 梯度下降
6.2 动量与加速
6.3 非线性共轭梯度法
6.4 收敛与计算成本
6.5 本章小结

非线性共轭梯度的 lim inf 结论并不保证最后一点最好，同样应保留历史最优点。无论哪种方法，宣布达到精度之前都应该在输出点处重新计算一次梯度，而不是用外推点的梯度代替，后者并不是输出点的残差。

6.5 本章小结

本章在只有函数值和梯度的条件下回答了“朝哪走、走多远、用不用历史”。负梯度是局部最陡的方向，二次上界决定一步能走多远，$\alpha = 1/L$ 保证每步下降。梯度下降的保证按假设分三档：非凸时梯度变小，凸时目标差按 $1/T$，强凸时按 $(1 - 1/\kappa)^T$。

病态的目标让步长被陡峭方向限制，平坦方向进展缓慢，步数与 κ 成正比。历史位移可以把一致的方向累积起来，把振荡的方向抵消。重球法在当前点读取梯度，在正定二次目标上把各方向的收缩因子拉平为 $(\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$，但这组参数离开二次目标可能循环。Nesterov 方法把梯度移到外推点，用势函数得到强凸时的 $(1 - 1/\sqrt{\kappa})^T$ 和凸时的 $1/T^2$，适用于一般的光滑目标，但函数值不必单调，目标非凸时定理不适用。

非线性共轭梯度保留上一方向，用线搜索决定步长，不需要曲率常数。FR 配合 $c_2 < \frac{1}{2}$ 的强 Wolfe 条件保证下降和 $\liminf \|\boldsymbol{g}^{(t)}\|_2 = 0$，容易卡顿；PRP 能自动重置，但需要 PRP+、充分下降或重启等附加规则才能谈收敛。正定二次目标上的共轭性和有限步终止，在非线性目标上都不能照搬。

比较这些方法时，保证的条件和度量必须对应，成本要按梯度读取和线搜索试探计入，迭代次数少不等于总计算少。这些方法对局部曲率的利用都是间接的：历史位移和梯度差只是曲率的影子。如果能直接计算或近似局部曲率，更新方向可以由二次模型给出，下一章由此建立 Newton 方向。

7.1 Newton 法
7.2 阻尼 Newton 法
7.3 修正 Newton 法
7.4 非精确 Newton 法
7.5 收敛与计算成本
7.6 本章小结

第 7 章

二阶方法

沿一条狭长的山谷下山，只看脚下的坡度是很吃亏的。坡度告诉我们哪边低，却不告诉我们这面坡还能延续多远：陡的方向走一点就到了谷底另一侧，缓的方向走很远才有变化。第 6章的方法靠步长和历史信息来缓解这种不匹配。假如还能读到二阶导数，就可以直接知道每个方向弯得有多厉害，并据此决定走多远。

本章研究这样得到的方法。出发点只有一句话：在当前点用二次函数近似目标，然后走到这个二次函数的极小点。第 7.1节由此导出 Newton 法，并说明它在解附近为什么快得惊人。

这句话照字面执行会遇到三种麻烦。离解很远时，二次函数和目标相差太大，走到它的极小点可能反而更差。曲率矩阵可能不正定，这时“二次函数的极小点”根本不存在。维数很高时，解一次线性方程本身就可能算不起。

三种麻烦分别由后面三节处理。第 7.2节不改方向，只缩短步长。第 7.3节改变曲率矩阵，让方向重新可用。第 7.4节允许线性方程解得不精确，并规定解到什么程度够用。三种手段针对不同的困难，可以单独使用，也可以组合。第 7.5节把它们放到相同的精度标准下，比较从起点到终点的全部计算量。

7.1 Newton 法

手里有当前点的梯度和 Hessian，下一步应该走到哪里，这样走在什么条件下是对的，又能快到什么程度？

用一个碗代替地形　设 $f:\mathbb{R}^n\to\mathbb{R}$ 二阶连续可微。站在 $\boldsymbol{x}^{(t)}$ 处，把目标在附近作二阶 Taylor 展开，保留到二次项，得到**局部二次模型**（local quadratic model）

$$m^{(t)}(\boldsymbol{d})=f(\boldsymbol{x}^{(t)})+(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}+\frac{1}{2}\boldsymbol{d}^{\top}\boldsymbol{H}^{(t)}\boldsymbol{d},\tag{7.1}$$

其中 $\boldsymbol{d}$ 是从当前点出发的位移，$\boldsymbol{g}^{(t)} = \nabla f(\boldsymbol{x}^{(t)})$，$\boldsymbol{H}^{(t)} = \nabla^2 f(\boldsymbol{x}^{(t)})$。Taylor 公式的余项估计可参考卷二第 20 章“多元函数微分”。

模型和目标在当前点有相同的函数值、斜率和弯曲程度。可以这样想：我们看不到整片地形，只能摸清脚下这一小块的坡度和弯度，于是用一只形状相同的碗去贴合脚下的地面。一阶方法只用一块斜板贴合，斜板告诉我们往哪边倒，却没有底；碗有底，底的位置就是模型给出的下一步。

这个比喻要记住它的限度。碗只在脚下贴合，$\|\boldsymbol{d}\|_2$ 越大，碗和地形的差别越大。后面几节的大部分工作都是在回答同一个问题：这只碗能信多远。

Newton 方程　当 $\boldsymbol{H}^{(t)}$ 正定时，模型是真正的碗，它的底由模型梯度为零确定。对式 (7.1)关于 $\boldsymbol{d}$ 求梯度并令其为零，得到

$$\boldsymbol{H}^{(t)}\boldsymbol{d}^{(t)} = -\boldsymbol{g}^{(t)}. \tag{7.2}$$

这个线性方程称为**Newton 方程**（Newton equation），解 $\boldsymbol{d}^{(t)}$ 称为**Newton 方向**（Newton direction）。走满这一步就是**Newton 法**（Newton’s method）：

$$\boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} + \boldsymbol{d}^{(t)}. \tag{7.3}$$

实际计算解方程 (7.2)，不求 $(\boldsymbol{H}^{(t)})^{-1}$。对称正定方程用 Cholesky 分解，稠密时约 $n^3/3$ 次运算；分解和回代的做法可参考卷二第 12 章“线性方程的直接求解”。

一元时方程 (7.2)就是 $f''(x)d = -f'(x)$。以 $f(x) = e^x - 2x$ 为例，最小点是 $x^\star = \ln 2 \approx 0.6931$。这时 $f'(x) = e^x - 2$，$f''(x) = e^x$，更新为

$$x^{(t+1)} = x^{(t)} - \frac{e^{x^{(t)}} - 2}{e^{x^{(t)}}} = x^{(t)} - 1 + 2e^{-x^{(t)}}.$$

从 $x^{(0)} = 1.5$ 出发，

$$x^{(1)} = 1.5 - 1 + 2e^{-1.5} \approx 0.9463.$$

一步就把误差从 0.807 降到 0.253。

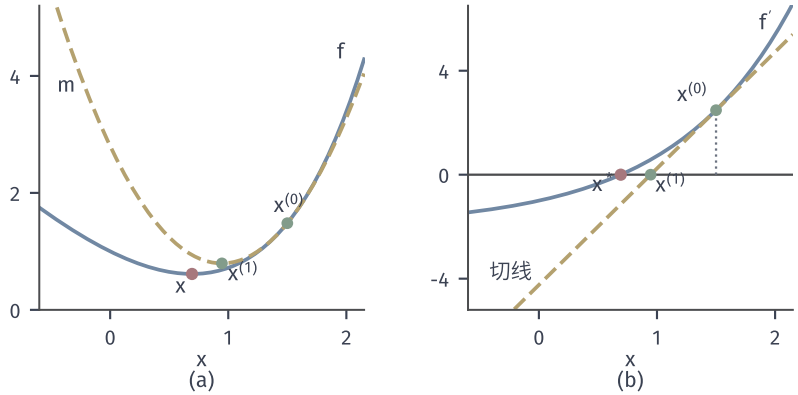


图 7.1 Newton 步的两种读法，目标为 $f(x)=e^x-2x$，$x^{(0)}=1.5$。(a) 蓝线是目标，黄色虚线是在 $x^{(0)}$ 处的二次模型，绿点 $x^{(1)}$ 是模型的极小点，红点是真正的最小点 $x^\star$。(b) 蓝线是导数 f'，黄色虚线是它在 $x^{(0)}$ 处的切线，切线与横轴的交点正是同一个 $x^{(1)}$。

图 7.1给出同一步的两种读法。图 (a) 是极小化的读法：用抛物线代替曲线，走到抛物线的底。图 (b) 是解方程的读法：要找 $\nabla f=\mathbf{0}$ 的根，就把 ∇f 在当前点线性化，再求线性函数的根。多元时，线性化 $\nabla f(\boldsymbol{x}^{(t)}+\boldsymbol{d})\approx \boldsymbol{g}^{(t)}+\boldsymbol{H}^{(t)}\boldsymbol{d}$ 再令其为零，得到的仍是式 (7.2)。

两种读法在正定时一致，但解方程的读法只找驻点，分不清极小点、极大点和鞍点。在 $\boldsymbol{H}^{(t)}$ 不正定的地方，两者会分道扬镳，这正是下面要讲的。

贯穿全章的例子 后面用同一个二元目标检验各种方法：

$$f(\boldsymbol{x})=\frac{1}{2}(x_1-1)^2+(x_2-x_1^2)^2. \tag{7.4}$$

两个平方项同时为零当且仅当 $\boldsymbol{x}=(1,1)$，所以 $\boldsymbol{x}^\star=(1,1)$，$f^\star=0$。第二项把点拉向抛物线 $x_2=x_1^2$，第一项才沿抛物线把点推向解，因此等高线是一条弯曲的山谷。

记 $u=x_2-x_1^2$。逐项求导，得到梯度和 Hessian：

$$\nabla f(\boldsymbol{x})=\begin{bmatrix} x_1-1-4x_1u \\ 2u \end{bmatrix},\qquad \nabla^2 f(\boldsymbol{x})=\begin{bmatrix} 1-4u+8x_1^2 & -4x_1 \\ -4x_1 & 2 \end{bmatrix}. \tag{7.5}$$

Hessian 的右下角元素是 $2>0$，行列式为

$$\det\nabla^2 f(\boldsymbol{x})=2(1-4u+8x_1^2)-16x_1^2=2(1-4u).$$

所以 $\nabla^2 f(\boldsymbol{x})$ 正定当且仅当 $1-4u>0$，也就是点在抛物线 $x_2=x_1^2+\frac{1}{4}$ 的下方。这条抛物线上方的区域里 Hessian 不定，下面的图都用红色浅底标出。

这个例子的 Newton 方程能手解。由第二行得 $d_2 = -u + 2x_1 d_1$，代入第一行，含 $8x_1^2$ 的项互相抵消，只剩 $(1-4u)d_1 = 1 - x_1$。于是，当 $1-4u \neq 0$ 时，

$$d_1 = \frac{1 - x_1}{1 - 4u}, \qquad d_2 = -u + 2x_1 d_1. \tag{7.6}$$

图 7.2比较模型和目标。在 $(\tfrac{1}{2}, 0)$ 附近，模型的黄色椭圆和目标的蓝色等高线相当接近，模型的底 $(\tfrac{3}{4}, \tfrac{1}{2})$ 确实比出发点低。在 $(-1, \tfrac{6}{5})$ 处情况完全不同：Hessian 的两个特征值约为 10.16 和 0.039，模型沿一个方向几乎是平的，由式 (7.6)算出模型的底远在 $(9, -19)$。

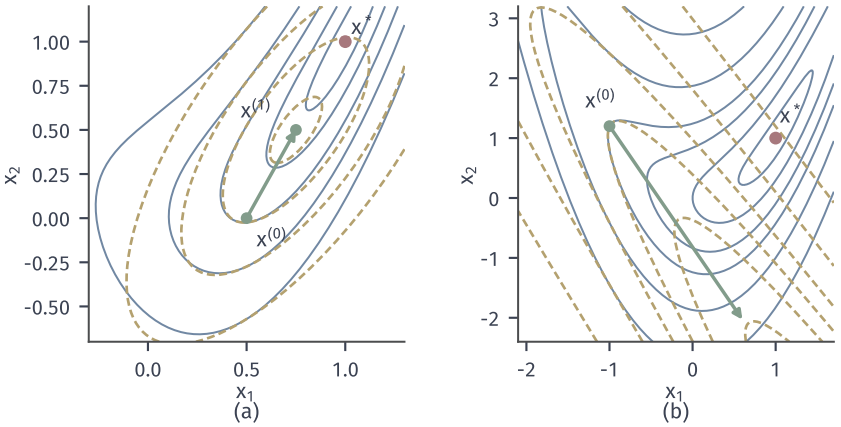


图 7.2　式 (7.4)的等高线（蓝）与局部模型的等高线（黄色虚线）。(a) 在 $(\tfrac{1}{2}, 0)$ 处模型贴合良好，绿色箭头是 Newton 步，它的终点 $\boldsymbol{x}^{(1)}$ 是模型的极小点。(b) 在 $(-1, \tfrac{6}{5})$ 处模型是一条几乎平直的长沟，绿色箭头按实际长度的 0.16 倍绘制，模型极小点 $(9, -19)$ 在图外。两图中红点都是 $\boldsymbol{x}^\star$。

可逆与正定各管什么　方程 (7.2)有唯一解只要求 $\boldsymbol{H}^{(t)}$ 可逆；这个解是模型的极小点、并且指向下坡，要求的是正定。下面的结论把这两件事分开。

引理 7.1　正定曲率下的 Newton 方向　设 $\boldsymbol{H}^{(t)} \succ \boldsymbol{0}$，$\boldsymbol{g}^{(t)} \neq \boldsymbol{0}$。则 $\boldsymbol{d}^{(t)} = -(\boldsymbol{H}^{(t)})^{-1}\boldsymbol{g}^{(t)}$ 是模型 (7.1)的唯一极小点，且满足

$$(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}^{(t)} = -(\boldsymbol{g}^{(t)})^{\top}(\boldsymbol{H}^{(t)})^{-1}\boldsymbol{g}^{(t)} < 0. \tag{7.7}$$

证明　省略上标。任取位移 $\boldsymbol{d}$，写成 $\boldsymbol{d} = \boldsymbol{d}^{(t)} + \boldsymbol{w}$ 代入模型。一次项中用 $\boldsymbol{g} = -\boldsymbol{H}\boldsymbol{d}^{(t)}$，含 $\boldsymbol{w}$ 的一次项互相抵消，得到

$$m(\boldsymbol{d}) = m(\boldsymbol{d}^{(t)}) + \frac{1}{2}\boldsymbol{w}^{\top}\boldsymbol{H}\boldsymbol{w}.$$

$\boldsymbol{H}$ 正定，所以 $\boldsymbol{w} \neq \boldsymbol{0}$ 时第二项严格为正，$\boldsymbol{d}^{(t)}$ 是唯一极小点。

> 下降性由定义代入得到。$\boldsymbol{H}$ 正定时 $\boldsymbol{H}^{-1}$ 也正定，而 $\boldsymbol{g} \neq \boldsymbol{0}$，于是二次型 $\boldsymbol{g}^{\top}\boldsymbol{H}^{-1}\boldsymbol{g}$ 严格为正。 ■

图 7.3用三种曲率说明不正定时会发生什么。图 (a) 的 $\boldsymbol{H}$ 正定，等高线是椭圆，方程的解是碗底。图 (b) 的 $\boldsymbol{H}$ 可逆但不定，方程仍有唯一解，那个点却是马鞍的中心，模型沿某些方向可以无限下降，“走到模型的底”这句话失去了意义。图 (c) 的 $\boldsymbol{H}$ 奇异，且 $\boldsymbol{g}$ 不在它的值域内，方程无解，模型沿平坦方向一直倾斜。

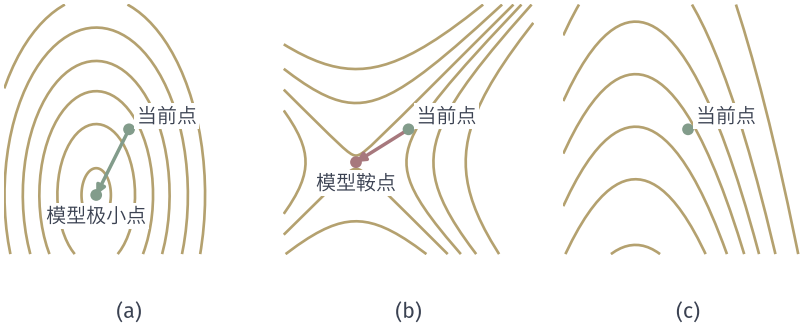


图 7.3　三种曲率下的局部模型，黄线为 $m(\boldsymbol{d})$ 的等高线，绿色圆点是当前点。(a)$\boldsymbol{H} = \operatorname{diag}(2, 0.6)$ 正定，Newton 方程的解是模型的极小点。(b)$\boldsymbol{H} = \operatorname{diag}(1, -1)$ 不定，方程的解是模型的鞍点，用红色标出。(c)$\boldsymbol{H} = \operatorname{diag}(1, 0)$ 奇异，$\boldsymbol{g} = (0.8, 0.5)$ 不在值域内，方程无解。

在例子中可以看到“不定”的具体后果。取 $\boldsymbol{x} = (0, \frac{1}{2})$，此时 $u = \frac{1}{2}$，$1 - 4u = -1 < 0$。由式 (7.5)，

$$\boldsymbol{g} = \begin{bmatrix} -1 \\ 1 \end{bmatrix}, \qquad \boldsymbol{H} = \begin{bmatrix} -1 & 0 \\ 0 & 2 \end{bmatrix}.$$

由式 (7.6)，Newton 方向是 $\boldsymbol{d} = (-1, -\frac{1}{2})$。方向导数为

$$\boldsymbol{g}^{\top}\boldsymbol{d} = 1 - \tfrac{1}{2} = \tfrac{1}{2} > 0,$$

所以这是一个上坡方向。走满一步到 $(-1, 0)$，目标从 0.75 升到 3。

下表把三种情形并排。

$\boldsymbol{H}^{(t)}$	方程 (7.2)	解的含义	方向
正定	唯一解	模型的唯一极小点	下降
可逆但不定	唯一解	模型的鞍点	可升可降
奇异	无解或无穷多解	无极小点或极小点不唯一	须另行处理

表 7.1　曲率矩阵的性质与 Newton 方程的解。可逆只回答方程能否解，正定才回答解是否有用。

不受坐标伸缩的影响　Newton 方向还有一个梯度方向没有的性质。第 6章的方法在病态目标上吃亏，原因是步子的大小和各方向的弯度不匹配。Newton 方向把弯度算进去了，因此和坐标的单位无关，就像一段路程不会因为改用千米记录而变长。

设 $\boldsymbol{A}$ 是可逆矩阵，令 $\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}$，$\tilde{f}(\boldsymbol{y})=f(\boldsymbol{A}^{-1}\boldsymbol{y})$。由链式法则，新坐标下的梯度和 Hessian 是

$$\nabla\tilde{f}=\boldsymbol{A}^{-\top}\boldsymbol{g},\qquad \nabla^2\tilde{f}=\boldsymbol{A}^{-\top}\boldsymbol{H}\boldsymbol{A}^{-1}.$$

代入 Newton 方程，$\boldsymbol{A}^{-\top}$ 互相抵消，新坐标下的方向是

$$\tilde{\boldsymbol{d}}=-\boldsymbol{A}\boldsymbol{H}^{-1}\boldsymbol{A}^{\top}\boldsymbol{A}^{-\top}\boldsymbol{g}=\boldsymbol{A}\boldsymbol{d}.$$

所以 $\tilde{\boldsymbol{d}}$ 恰好是原方向 $\boldsymbol{d}$ 在新坐标下的样子，整条迭代序列只是被 $\boldsymbol{A}$ 映到了新坐标，这称为**仿射不变性**（affine invariance）。

负梯度方向不同。新坐标下它是 $-\boldsymbol{A}^{-\top}\boldsymbol{g}$，而把原方向 $-\boldsymbol{g}$ 映过去是 $-\boldsymbol{A}\boldsymbol{g}$，两者只在 $\boldsymbol{A}$ 为正交矩阵的倍数时平行。

图 7.4以 $f(\boldsymbol{x})=\frac{1}{2}(x_1^2+25x_2^2)$ 为例，条件数是 25。Newton 方向 $\boldsymbol{d}=-\boldsymbol{H}^{-1}\boldsymbol{H}\boldsymbol{x}=-\boldsymbol{x}$，从任何起点都一步到达最小点，这对任意正定二次目标都成立。使用精确线搜索的梯度下降在原坐标下往复前进；换坐标 $y_2=5x_2$ 后，等高线成了圆，两种方法才走同一条路。

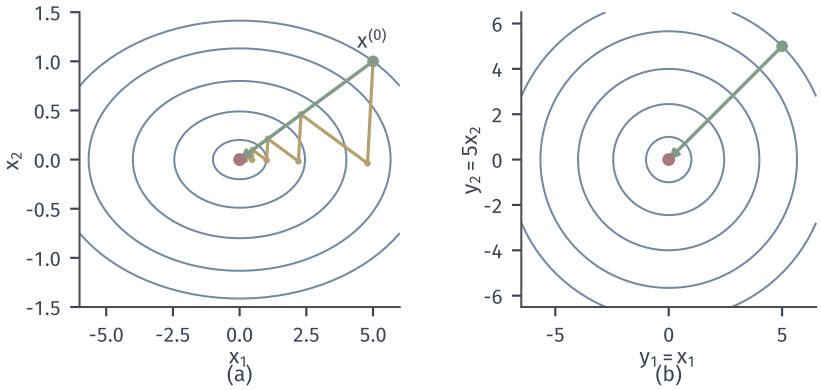


图 7.4　坐标变换对两种方向的影响，目标 $\frac{1}{2}(x_1^2 + 25x_2^2)$。(a) 原坐标，从 $(5, 1)$ 出发，黄色折线是精确线搜索的梯度下降，绿色箭头是 Newton 步，红点是最小点。(b) 取 $y_2 = 5x_2$ 后等高线为圆，负梯度方向和 Newton 方向重合。Newton 步在两张图中是同一步，只是用不同坐标表示。

仿射不变性说的是精确算术下的迭代。实际解方程时，$\boldsymbol{H}^{(t)}$ 的条件数仍然影响舍入误差，只是它不再决定迭代步数。

计算过程　Newton 法的公式已经由式 (7.2)、(7.3)给出。下面用目标 (7.4)从 $(\frac{1}{2}, 0)$ 出发走一遍。这一节假定每个迭代点的 Hessian 都正定；不正定的情形由第 7.3节处理。

变量

- $\boldsymbol{x} \in \mathbb{R}^n$：当前点 $\boldsymbol{x}^{(t)}$，在原处更新。
- $\boldsymbol{g} \in \mathbb{R}^n$：当前梯度。
- $\boldsymbol{H} \in \mathbb{R}^{n \times n}$：当前 Hessian，对称。
- $\boldsymbol{L} \in \mathbb{R}^{n \times n}$：下三角矩阵，$\boldsymbol{H}$ 的 Cholesky 因子。
- $\boldsymbol{d} \in \mathbb{R}^n$：Newton 方向。
- $\varepsilon > 0$：梯度容差。

初始化　选定初始点 $\boldsymbol{x}^{(0)}$ 和容差 ε，令 $t = 0$。例中初始点和容差为

$$\boldsymbol{x}^{(0)} = \left(\tfrac{1}{2}, 0\right), \qquad \varepsilon = 10^{-6}.$$

每轮更新　在第 t 轮：

1. **读取导数并检查停止**。计算 $\boldsymbol{g}^{(t)}$ 和 $\boldsymbol{H}^{(t)}$。若 $\|\boldsymbol{g}^{(t)}\|_2 \le \varepsilon$，输出 $\boldsymbol{x}^{(t)}$ 并结束。

   例中第一轮 $u = -\tfrac{1}{4}$，由式 (7.5)，

$$\boldsymbol{g}^{(0)} = \begin{bmatrix} 0 \\ -\tfrac{1}{2} \end{bmatrix}, \qquad \boldsymbol{H}^{(0)} = \begin{bmatrix} 4 & -2 \\ -2 & 2 \end{bmatrix}.$$

2. **分解**。计算 Cholesky 分解 $\boldsymbol{H}^{(t)} = \boldsymbol{L}\boldsymbol{L}^{\top}$。

   例中第一轮

$$\boldsymbol{L} = \begin{bmatrix} 2 & 0 \\ -1 & 1 \end{bmatrix}.$$

3. **回代求方向**。先由前代解 $\boldsymbol{L}\boldsymbol{y} = -\boldsymbol{g}^{(t)}$，再由回代解 $\boldsymbol{L}^{\top}\boldsymbol{d}^{(t)} = \boldsymbol{y}$。

   例中第一轮的中间向量和方向分别是

$$\boldsymbol{y} = \begin{bmatrix} 0 \\ \tfrac{1}{2} \end{bmatrix}, \qquad \boldsymbol{d}^{(0)} = \begin{bmatrix} \tfrac{1}{4} \\ \tfrac{1}{2} \end{bmatrix}.$$

4. **更新**。按式 (7.3)走到下一点，令 $t \leftarrow t+1$。

   例中第一轮到达 $\boldsymbol{x}^{(1)} = (\tfrac{3}{4}, \tfrac{1}{2})$，目标从 $\tfrac{3}{16}$ 降到 $\tfrac{9}{256} \approx 0.0352$。

   第二轮 $u = \tfrac{1}{2} - \tfrac{9}{16} = -\tfrac{1}{16}$。这时用手解直接套式 (7.6)更快：

$$d_1 = \frac{1/4}{1 + 1/4} = \frac{1}{5}, \qquad d_2 = \frac{1}{16} + \frac{3}{2}\cdot\frac{1}{5} = 0.3625.$$

   于是 $\boldsymbol{x}^{(2)} = (0.95, 0.8625)$，目标降到 0.00285。

各轮结果列在表 7.2中。第 5 轮梯度范数已低于容差，迭代结束，最终得到 $\boldsymbol{x}^{(5)} \approx (1,1)$，与解的距离约 2.4×10^{-8}。图 7.5画出了前几步的路径。

t	$\boldsymbol{x}^{(t)}$	f	$\|\boldsymbol{g}^{(t)}\|_2$	$\boldsymbol{d}^{(t)}$	$\|\boldsymbol{x}^{(t)} - \boldsymbol{x}^{\star}\|_2$
0	$(0.5, 0)$	0.1875	0.5	$(0.25, 0.5)$	1.118
1	$(0.75, 0.5)$	0.03516	0.1398	$(0.2, 0.3625)$	0.5590
2	$(0.95, 0.8625)$	2.85e−3	0.1296	$(0.0431, 0.1219)$	0.1463
3	$(0.9931, 0.9844)$	2.72e−5	3.75e−3	$(0.0068, 0.0155)$	0.01706
4	$(0.99995, 0.99985)$	3.49e−9	1.66e−4	$(5\text{e}{-5}, 1.5\text{e}{-4})$	1.57e−4
5	$(1.0000, 1.0000)$	5.2e−17	5.2e−9	停止	2.4e−8

表 7.2　Newton 法在目标 (7.4)上从 $(\tfrac{1}{2}, 0)$ 出发的迭代。第 3 行以后，误差每步大约平方一次。

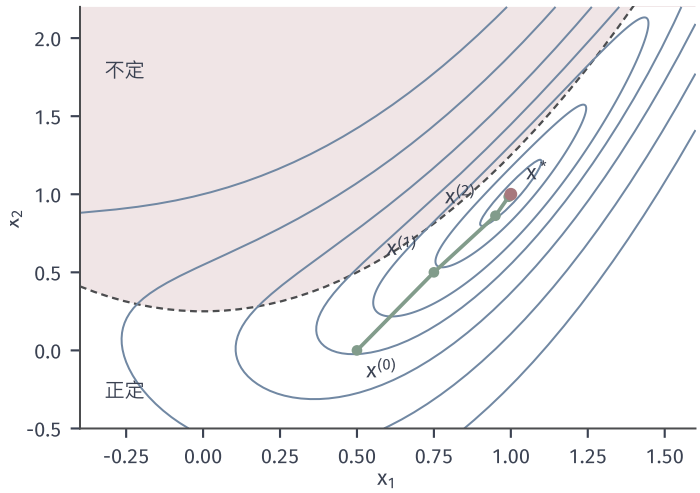


图 7.5 Newton 法的迭代路径（绿）。蓝线是目标 (7.4)的等高线，红色浅底是 Hessian 不定的区域，深灰色虚线是它的边界 $x_2 = x_1^2 + \frac{1}{4}$，红点是解。起点 $(\frac{1}{2}, 0)$ 在正定区域内，路径紧贴山谷前进，始终没有进入浅底区域。

路径始终在正定区域内，这一点在本例中可以验证。整步之后的 u 值为

$$u^+ = (x_2 + d_2) - (x_1 + d_1)^2 = u + d_2 - 2x_1 d_1 - d_1^2.$$

代入式 (7.6)的 d_2，前三项相消，得到

$$u^+ = -d_1^2 \le 0.$$

因此任意一个完整 Newton 步之后都有 $1 - 4u^+ \ge 1 > 0$。这是此目标特有的结构，一般目标没有这样的保证。

局部二次收敛 表 7.2最后几行显示，误差接近解时每步大约平方一次。下面说明这种现象来自哪里。先从直观上看：在解附近，目标和它的二次模型只差三阶小量；二次模型的极小点又恰好由 Newton 步算出，所以 Newton 步的误差只由这个三阶差决定，比一阶方法“每步打一个固定折扣”好得多。

称一列点**二次收敛** (quadratic convergence) 到 $\boldsymbol{x}^\star$，如果存在常数 C，使充分大的 t 都满足

$$\|\boldsymbol{x}^{(t+1)} - \boldsymbol{x}^\star\|_2 \le C\|\boldsymbol{x}^{(t)} - \boldsymbol{x}^\star\|_2^2. \tag{7.8}$$

定理需要在解附近控制 Hessian，记 μ 为解处 Hessian 的最小特征值，M 为 Hessian 的 Lipschitz 常数。

定理 7.2　Newton 法的局部二次收敛　设 f 在以 $\boldsymbol{x}^\star$ 为中心、半径为 r 的开球 $\boldsymbol{B}$ 上二阶连续可微，$\nabla f(\boldsymbol{x}^\star)=\boldsymbol{0}$，$\nabla^2 f(\boldsymbol{x}^\star)\succeq \mu \boldsymbol{I}$，其中 $\mu>0$，并且对 $\boldsymbol{x},\boldsymbol{y}\in\boldsymbol{B}$ 有

$$\|\nabla^2 f(\boldsymbol{x})-\nabla^2 f(\boldsymbol{y})\|_2 \le M\|\boldsymbol{x}-\boldsymbol{y}\|_2. \tag{7.9}$$

记 $\rho=\min\{r,\ \mu/(2M)\}$。若 $\|\boldsymbol{x}^{(t)}-\boldsymbol{x}^\star\|_2<\rho$，则 $\boldsymbol{H}^{(t)}\succeq \frac{\mu}{2}\boldsymbol{I}$，Newton 步有定义，且

$$\|\boldsymbol{x}^{(t+1)}-\boldsymbol{x}^\star\|_2 \le \frac{M}{\mu}\|\boldsymbol{x}^{(t)}-\boldsymbol{x}^\star\|_2^2. \tag{7.10}$$

因此，只要 $\|\boldsymbol{x}^{(0)}-\boldsymbol{x}^\star\|_2<\rho$，所有迭代点都留在半径 ρ 的球内，并且

$$\frac{M}{\mu}\|\boldsymbol{x}^{(t)}-\boldsymbol{x}^\star\|_2 \le \left(\frac{1}{2}\right)^{2^t}. \tag{7.11}$$

证明　记 $\boldsymbol{e}=\boldsymbol{x}^{(t)}-\boldsymbol{x}^\star$，$\boldsymbol{H}=\boldsymbol{H}^{(t)}$，并设 $\|\boldsymbol{e}\|_2<\rho$。

第一步说明 $\boldsymbol{H}$ 的逆有界。由式 (7.9)，

$$\|\boldsymbol{H}-\nabla^2 f(\boldsymbol{x}^\star)\|_2 \le M\|\boldsymbol{e}\|_2 \le \frac{\mu}{2}.$$

对称矩阵的特征值受扰动量控制，所以 $\lambda_{\min}(\boldsymbol{H})\ge \mu-\mu/2$，即

$$\boldsymbol{H}\succeq\frac{\mu}{2}\boldsymbol{I},\qquad \|\boldsymbol{H}^{-1}\|_2\le\frac{2}{\mu}.$$

第二步写出误差的递推。由 $\nabla f(\boldsymbol{x}^\star)=\boldsymbol{0}$，沿线段积分，

$$\boldsymbol{g}^{(t)}=\int_0^1 \nabla^2 f(\boldsymbol{x}^\star+s\boldsymbol{e})\boldsymbol{e}\,\mathrm{d}s.$$

Newton 步之后的误差是 $\boldsymbol{e}-\boldsymbol{H}^{-1}\boldsymbol{g}^{(t)}$。把 $\boldsymbol{e}$ 写成 $\boldsymbol{H}^{-1}\boldsymbol{H}\boldsymbol{e}$ 并合并，得到

$$\boldsymbol{x}^{(t+1)}-\boldsymbol{x}^\star=\boldsymbol{H}^{-1}\int_0^1\big(\boldsymbol{H}-\nabla^2 f(\boldsymbol{x}^\star+s\boldsymbol{e})\big)\boldsymbol{e}\,\mathrm{d}s.$$

第三步估计积分。点 $\boldsymbol{x}^{(t)}$ 与 $\boldsymbol{x}^\star+s\boldsymbol{e}$ 相距 $(1-s)\|\boldsymbol{e}\|_2$，由式 (7.9)，

$$\left\|\int_0^1\big(\boldsymbol{H}-\nabla^2 f(\boldsymbol{x}^\star+s\boldsymbol{e})\big)\boldsymbol{e}\,\mathrm{d}s\right\|_2 \le \int_0^1 M(1-s)\|\boldsymbol{e}\|_2^2\,\mathrm{d}s=\frac{M}{2}\|\boldsymbol{e}\|_2^2.$$

与第一步的 $2/\mu$ 相乘，即得式 (7.10)。

最后讨论序列。记

$$a_t = \frac{M}{\mu}\|\boldsymbol{x}^{(t)} - \boldsymbol{x}^\star\|_2,$$

式 (7.10)写成 $a_{t+1} \le a_t^2$。由初始距离小于 $\rho \le \mu/(2M)$ 得 $a_0 < \tfrac{1}{2}$。于是误差每步至少减半，迭代点不离开球，归纳得 $a_t \le a_0^{2^t} \le (\tfrac{1}{2})^{2^t}$。 ■

式 (7.11)说明，进入这个邻域后，有效数字大约每步翻倍。回到 $f(x) = e^x - 2x$，从 1.5 出发的误差依次是

$$0.807,\quad 0.253,\quad 0.0295,\quad 4.31\times10^{-4},\quad 9.27\times10^{-8},\quad 4.33\times10^{-15}.$$

相邻两步的比值 $e^{(t+1)}/(e^{(t)})^2$ 依次约为

$$0.39,\quad 0.46,\quad 0.50,\quad 0.50,\quad 0.50,$$

趋于 $f'''(x^\star)/(2f''(x^\star)) = \tfrac{1}{2}$。

对主例 (7.4),解处 Hessian 的特征值约为 0.185 和 10.8,所以 $\mu \approx 0.185$；在解附近数值估计 $M \approx 25$，定理保证的半径 $\mu/(2M)$ 只有约 0.0037。表 7.2的迭代却从距离 1.1 处就进展顺利。定理给出的是充分条件，半径通常十分保守；它的价值在于说明快速收敛的机制和所需的条件。

图 7.6(a) 比较了同一起点上的 Newton 法和使用回溯线搜索的梯度下降，后者的步长规则由下一节的式 (7.14)规定。解处的条件数约为 58，梯度下降要 245 步才能把梯度范数降到 10^{-6}，Newton 法用了 5 步。

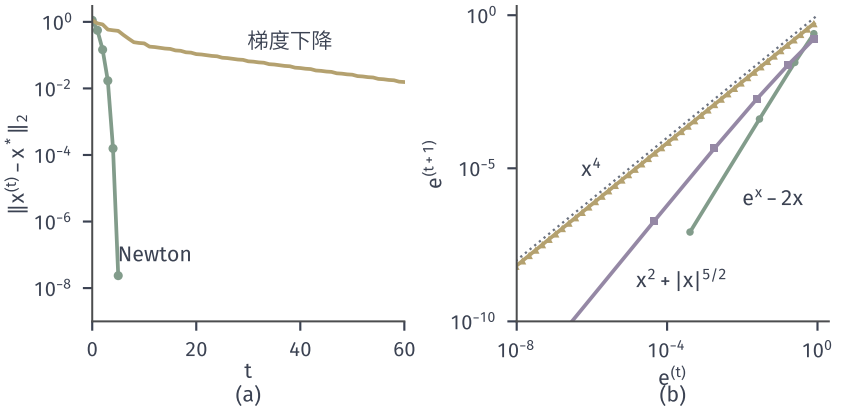


图 7.6　收敛阶的比较。(a) 目标 (7.4)上从 $(\tfrac{1}{2}, 0)$ 出发的距离误差，绿线为 Newton 法，黄线为回溯梯度下降。(b) 双对数坐标下相邻两步一维误差的关系：绿线 $e^x - 2x$ 斜率约为 2，紫线 $x^2 + |x|^{5/2}$ 斜率约为 1.5，黄线 x^4 斜率为 1 且接近灰色虚线 $e^{(t+1)} = e^{(t)}$。

三个条件的作用　定理有三个条件：解处 Hessian 正定、Hessian Lipschitz 连续、初始点足够近。逐一去掉，可以看到结论怎样变弱。

去掉解处正定，看 $f(x)=x^4$。解是 0，但 $f''(0)=0$，这是退化的极小点。Newton 更新为

$$x^{(t+1)} = x^{(t)} - \frac{4(x^{(t)})^3}{12(x^{(t)})^2} = \frac{2}{3}x^{(t)}.$$

收敛只是线性的，误差每步乘以固定的 $\frac{2}{3}$。式 (7.10)中的 M/μ 此时为无穷大，模型的底沿平坦方向已不再贴近真解。

去掉 Hessian 的 Lipschitz 连续，看 $f(x)=x^2+|x|^{5/2}$。它的解是 0，$f''(0)=2$，但 f'' 在 0 处只是 $\frac{1}{2}$ 阶 Hölder 连续。对 $x>0$，

$$f'(x)=2x+\tfrac{5}{2}x^{3/2}, \qquad f''(x)=2+\tfrac{15}{4}x^{1/2}.$$

代入 Newton 更新并通分，分子中的一次项抵消，得到

$$x^{(t+1)} = \frac{\frac{5}{4}(x^{(t)})^{3/2}}{2+\frac{15}{4}(x^{(t)})^{1/2}} \approx \frac{5}{8}(x^{(t)})^{3/2}.$$

误差的阶从 2 降为 $\frac{3}{2}$，仍快于线性，但不再是二次。图 7.6(b) 中三条线的斜率正是收敛阶。

去掉初始点足够近，看严格凸函数 $\varphi(x)=\sqrt{1+x^2}$。求导得

$$\varphi'(x)=\frac{x}{\sqrt{1+x^2}}, \qquad \varphi''(x)=(1+x^2)^{-3/2}.$$

代入 Newton 更新，得到极简的递推

$$x^{(t+1)} = x^{(t)} - x^{(t)}\bigl(1+(x^{(t)})^2\bigr) = -(x^{(t)})^3. \tag{7.12}$$

$|x^{(0)}|<1$ 时迭代收敛，$|x^{(0)}|=1$ 时在 ±1 之间来回跳，$|x^{(0)}|>1$ 时发散。图 7.7(a) 说明了原因：x 很大时函数几乎是直线，曲率很小，模型的底在非常远的地方。这个函数处处解析、处处严格凸，Newton 法照样发散，所以局部定理中的“足够近”不能省略。

7.1 Newton 法
7.2 阻尼 Newton 法
7.3 修正 Newton 法
7.4 非精确 Newton 法
7.5 收敛与计算成本
7.6 本章小结

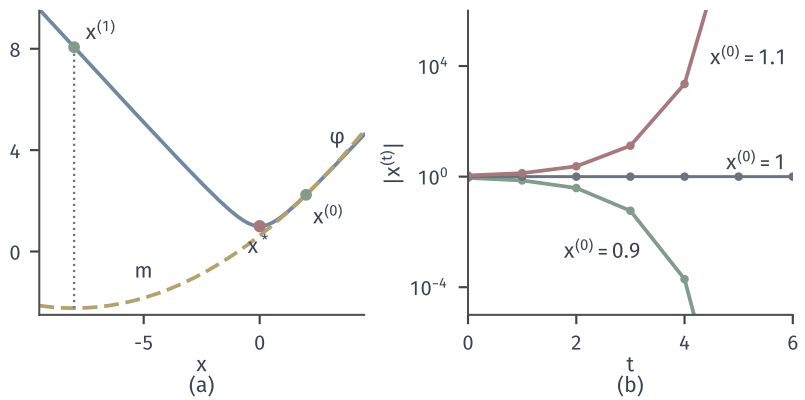


图 7.7 严格凸函数 $\varphi(x)=\sqrt{1+x^2}$ 上 Newton 法的局部性。(a) 蓝线是 φ，黄色虚线是 $x^{(0)}=2$ 处的二次模型，模型的底在 $x=-8$，绿点标出实际到达的新点，φ 反而升高。(b) 递推 $x^{(t+1)}=-(x^{(t)})^3$ 的三条轨迹，纵轴为绝对值，初值分别为 0.9（绿）、1（灰）、1.1（红）。

7.2 阻尼 Newton 法

上一节的定理只管解附近。接下来要弄清：Hessian 仍然正定，但当前点离解很远，模型的底不可信，怎样在不改变方向的前提下保证目标确实下降，又不损失解附近的快速收敛？

完整 Newton 步的麻烦 回到目标 (7.4)，从 $\boldsymbol{x}^{(0)}=(-1,\frac{6}{5})$ 出发。此处 $u=\frac{1}{5}$，Hessian 的行列式是 $2(1-4u)=0.4$，正定但接近奇异。由式 (7.6)，

$$d_1=\frac{2}{0.2}=10,\qquad d_2=-\frac{1}{5}-2\cdot 10=-20.2.$$

走满一步到达 $(9,-19)$，目标从 2.04 升到 10032。

Newton 方向在这里是下降方向，毛病出在走得太远。按式 (7.6)继续走完整步，迭代点在 $(9,-19)$、$(8.98,80.6)$、$(1.01,-62.5)$ 之间大幅跳动，几步之后才落回解附近，见图 7.9(a)。这条路径能回来，靠的是上一节提到的此目标的特殊结构。一般目标没有这种运气，式 (7.12)的发散就是例子。

主要思想 Newton 方向是模型认为最好的方向，模型的问题主要在于它在远处高估了自己。一个自然的补救是保留方向，但只走其中的一段，走多少由原目标来核验：

$$\boldsymbol{x}^{(t+1)}=\boldsymbol{x}^{(t)}+\alpha^{(t)}\boldsymbol{d}^{(t)},\qquad 0<\alpha^{(t)}\le 1. \tag{7.13}$$

这称为**阻尼 Newton 法**（damped Newton method）。方向仍由方程 (7.2)确定，改变的只是这一步信模型信到什么程度。

核验用第 5章的 Armijo 条件。给定 $c \in (0, \frac{1}{2})$，要求实际下降至少达到一阶预测的 c 倍：

$$f(\boldsymbol{x}^{(t)} + \alpha \boldsymbol{d}^{(t)}) \le f(\boldsymbol{x}^{(t)}) + c\,\alpha\,(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}^{(t)}. \tag{7.14}$$

回溯的做法是先试 $\alpha = 1$，不满足就乘以 $\beta \in (0,1)$，直到满足为止。上限取 1、并且先试 1，理由在本节后面说明。

方向导数 $(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}^{(t)}$ 在这里有专门的意义。记

$$(\omega^{(t)})^2 = -(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}^{(t)} = (\boldsymbol{g}^{(t)})^{\top}(\boldsymbol{H}^{(t)})^{-1}\boldsymbol{g}^{(t)}. \tag{7.15}$$

$\omega^{(t)}$ 称为Newton 减量（Newton decrement）。把 $\boldsymbol{d}^{(t)}$ 代入模型，再用 $\boldsymbol{H}^{(t)}\boldsymbol{d}^{(t)} = -\boldsymbol{g}^{(t)}$，得到模型的预测下降量

$$m^{(t)}(\boldsymbol{0}) - m^{(t)}(\boldsymbol{d}^{(t)}) = \frac{1}{2}(\omega^{(t)})^2.$$

所以 $\frac{1}{2}(\omega^{(t)})^2$ 是模型对“还能下降多少”的估计，可以作为停止标准。它和 Newton 方向一样不受坐标伸缩影响，梯度范数则没有这种性质。

正定性为回溯提供了什么　回溯要能结束，当前方向必须是下降方向。由式 (7.7)，$\boldsymbol{H}^{(t)} \succ \boldsymbol{0}$ 时 $(\omega^{(t)})^2 > 0$。把目标限制在这个方向上，记一元函数 $\varphi(\alpha)$ 为沿方向走 α 时的目标值，它在 0 处的导数是 $-(\omega^{(t)})^2 < 0$，于是

$$\varphi(\alpha) = \varphi(0) - \alpha(\omega^{(t)})^2 + o(\alpha).$$

由于 $c < 1$，当 α 足够小时，式 (7.14)成立，回溯在有限次内结束。

如果 $\boldsymbol{H}^{(t)}$ 不定，这个保证就没有了。第 7.1节的点 $(0, \frac{1}{2})$ 处方向导数为 $\frac{1}{2} > 0$，式 (7.14)的右端随 α 增大而升高，而左端在小 α 上升得比右端更快，因为 $c < 1$。无论 α 多小都不满足，回溯永远停不下来。阻尼只能调整走多远，不能把上坡的方向变成下坡。

计算过程　仍用目标 (7.4)，从上面的坏起点 $(-1, \frac{6}{5})$ 出发。

变量

- $\boldsymbol{x}, \boldsymbol{g}, \boldsymbol{H}, \boldsymbol{d}$：与 Newton 法相同，分别是当前点、梯度、Hessian 和 Newton 方向。
- ω^2：Newton 减量的平方，同时是方向导数的相反数。
- α：当前试探步长，每轮从 1 开始。
- c, β：Armijo 参数和回溯因子，全程固定。

- ε：停止容差，判断 $\frac{1}{2}\omega^2 \le \varepsilon$。

初始化 选定 $\boldsymbol{x}^{(0)}$，$c \in (0, \frac{1}{2})$，$\beta \in (0,1)$，$\varepsilon > 0$。例中取下面的数据：

$$\boldsymbol{x}^{(0)} = \left(-1, \tfrac{6}{5}\right), \qquad c = 0.1, \qquad \beta = 0.5, \qquad \varepsilon = 10^{-10}.$$

每轮更新 在第 t 轮：

1. **求 Newton 方向**。计算 $\boldsymbol{g}^{(t)}$、$\boldsymbol{H}^{(t)}$，用 Cholesky 分解解方程 (7.2)。

   例中第一轮

$$\boldsymbol{g}^{(0)} = \begin{bmatrix} -1.2 \\ 0.4 \end{bmatrix}, \qquad \boldsymbol{H}^{(0)} = \begin{bmatrix} 8.2 & 4 \\ 4 & 2 \end{bmatrix}, \qquad \boldsymbol{d}^{(0)} = \begin{bmatrix} 10 \\ -20.2 \end{bmatrix}.$$

2. **检查停止**。按式 (7.15)计算 ω^2。若 $\frac{1}{2}\omega^2 \le \varepsilon$，输出 $\boldsymbol{x}^{(t)}$ 并结束。

   例中第一轮

$$(\omega^{(0)})^2 = 12 + 8.08 = 20.08.$$

3. **回溯**。令 $\alpha = 1$。当式 (7.14)不成立时，令 $\alpha \leftarrow \beta\alpha$。

   例中第一轮的右端是 $2.04 - 2.008\alpha$，试探结果如下：

α	1	1/2	1/4	1/8
$f(\boldsymbol{x}^{(0)} + \alpha \boldsymbol{d}^{(0)})$	10032	624.5	37.34	2.206
右端	0.032	1.036	1.538	1.789

   四次都被拒绝。下一次试探 $\alpha = \frac{1}{16}$，新点是 $(-0.375, -0.0625)$，目标值 0.9866，右端 1.9145，条件满足，接受。

4. **更新**。按式 (7.13)走到下一点，令 $t \leftarrow t + 1$。

   例中第一轮到达 $\boldsymbol{x}^{(1)} = (-0.375, -0.0625)$。

   第二轮 $u = -0.203125$，由式 (7.5)和式 (7.6)，

$$\boldsymbol{g}^{(1)} = \begin{bmatrix} -1.6797 \\ -0.4063 \end{bmatrix}, \qquad \boldsymbol{d}^{(1)} = \begin{bmatrix} 0.7586 \\ -0.3658 \end{bmatrix}, \qquad (\omega^{(1)})^2 = 1.1256.$$

   试探 $\alpha = 1$，新点的目标值是 0.5212，右端是 $0.9866 - 0.1126 = 0.8740$，第一次试探即被接受。

图 7.8是第一轮回溯的情形。表 7.3列出各轮结果。第 1 轮以后每次都是 $\alpha = 1$ 第一次就被接受。第 7 轮 $\frac{1}{2}\omega^2$ 已低于容差，迭代结束，最终得到 $\boldsymbol{x}^{(7)} \approx (1,1)$，目标值约 7.6×10^{-15}。

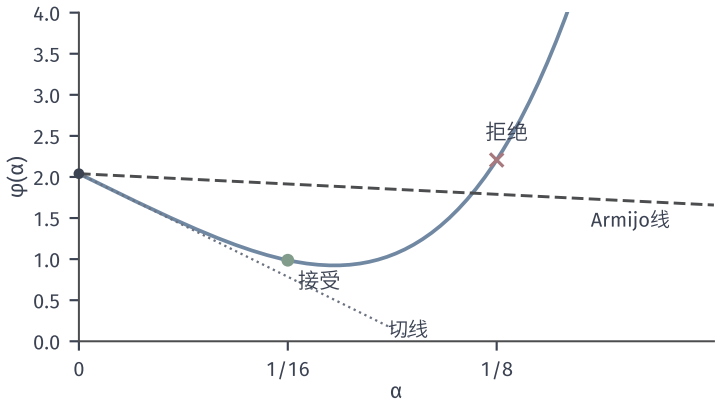


图 7.8　第一轮回溯沿方向的一元函数 $\varphi(\alpha) = f(\boldsymbol{x}^{(0)} + \alpha \boldsymbol{d}^{(0)})$（蓝）。灰色点线是 $\alpha = 0$ 处的切线，深灰色虚线是 Armijo 线 $\varphi(0) + c\alpha\varphi'(0)$，曲线在 Armijo 线下方的步长才可接受。$\alpha = \frac{1}{8}$ 处（红叉）目标在线上方，被拒绝；$\alpha = \frac{1}{16}$ 处（绿点）被接受。$\alpha = 1, \frac{1}{2}, \frac{1}{4}$ 在图外，目标值更高。

t	$\boldsymbol{x}^{(t)}$	f	$(\omega^{(t)})^2$	$\alpha^{(t)}$
0	$(-1, 1.2)$	2.04	20.08	1/16
1	$(-0.375, -0.0625)$	0.9866	1.1256	1
2	$(0.3836, -0.4283)$	0.5212	0.7775	1
3	$(0.5703, 0.2904)$	0.09354	0.1645	1
4	$(0.9474, 0.7554)$	0.02161	0.04223	1
5	$(0.9809, 0.9611)$	1.83e−4	3.64e−4	1
6	$(0.99992, 0.99947)$	1.33e−7	2.67e−7	1
7	$(1.0000, 1.0000)$	7.6e−15	1.5e−14	停止

表 7.3　阻尼 Newton 法从 $(-1, \frac{6}{5})$ 出发的迭代，$c = 0.1$，$\beta = 0.5$。只有第一轮的方向需要缩短，其余各轮都接受完整步。

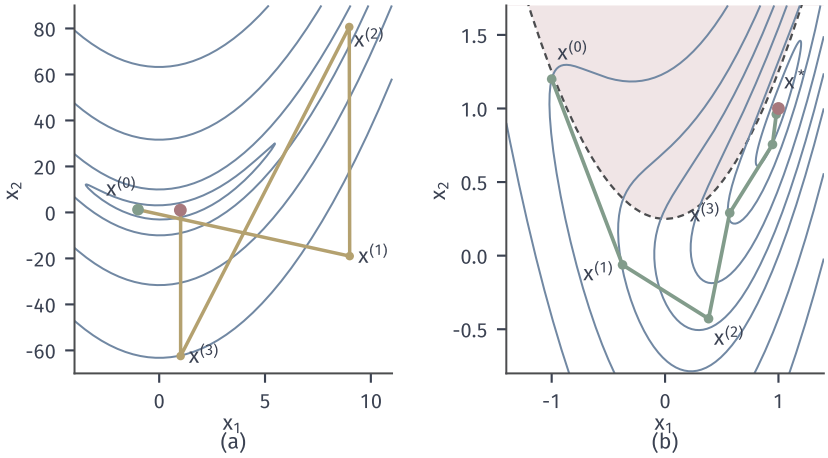


图 7.9　从 $(-1, \frac{6}{5})$ 出发的两条路径，蓝线是等高线，红点是解。(a) 完整 Newton 步（黄）在大范围内来回跳动，纵轴范围约 160。(b) 阻尼 Newton 法（绿）第一步只走 $\frac{1}{16}$，随后沿山谷收敛，红色浅底是 Hessian 不定的区域。

图 7.10把目标值和步长画成曲线。完整 Newton 步的目标值先冲到 10^4 的量级，阻尼方法则严格逐步下降。值得注意的是，完整步的路径从第 4 轮起目标值反而更低，因为它恰好跳到了解附近；阻尼保证的是每一步可靠，并不保证每条路径的步数都最少。

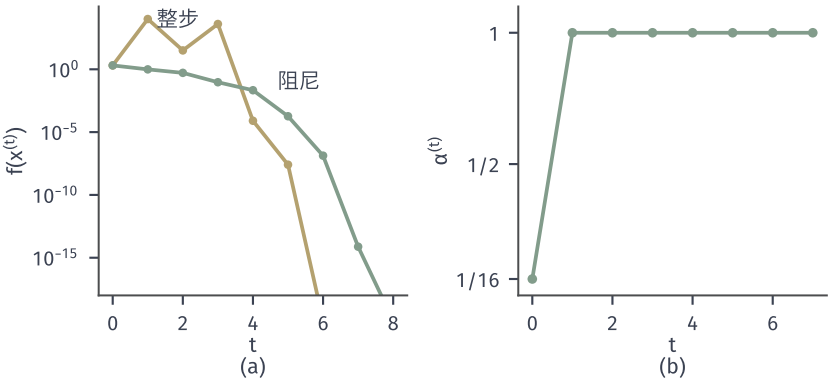


图 7.10　图 7.9两条路径的数值。(a) 目标值的半对数曲线，绿线为阻尼 Newton 法，黄线为完整 Newton 步。(b) 阻尼 Newton 法各轮接受的步长，第一轮之后都是 1。

强凸目标上的全局收敛　现在把“回溯总能带来足够下降”写成定理。定理需要曲率的上下界，用来保证方向既不太长也不太偏。假设对全空间成立是为了证明简洁；真正用到的只是初始下水平集附近的界，这时要额外说明所有试探点留在该区域内。

定理 7.3　阻尼 Newton 法的全局线性收敛　设 f 二阶连续可微，且对所有 $\boldsymbol{x}$，$\mu \boldsymbol{I} \preceq \nabla^2 f(\boldsymbol{x}) \preceq L\boldsymbol{I}$，其中 $0 < \mu \le L$，记 $\kappa = L/\mu$。取 $c \in (0, \tfrac{1}{2})$，$\beta \in (0,1)$。则回溯总在有限次内结束，接受的步长满足 $\alpha^{(t)} \ge \beta/\kappa$，并且

$$f(\boldsymbol{x}^{(t+1)}) - f^\star \le \Big(1 - \frac{2c\beta}{\kappa^2}\Big)\big(f(\boldsymbol{x}^{(t)}) - f^\star\big). \tag{7.16}$$

证明　省略上标。第一步估计沿方向的上界。曲率上界 L 给出

$$f(\boldsymbol{x} + \alpha \boldsymbol{d}) \le f(\boldsymbol{x}) + \alpha \boldsymbol{g}^\top \boldsymbol{d} + \frac{L}{2}\alpha^2 \|\boldsymbol{d}\|_2^2.$$

由式 (7.15)，$\boldsymbol{g}^\top \boldsymbol{d} = -\omega^2$。又由 $\boldsymbol{H} \succeq \mu \boldsymbol{I}$，

$$\omega^2 = \boldsymbol{d}^\top \boldsymbol{H} \boldsymbol{d} \ge \mu \|\boldsymbol{d}\|_2^2.$$

代入上式，

$$f(\boldsymbol{x} + \alpha \boldsymbol{d}) \le f(\boldsymbol{x}) - \alpha\omega^2 + \frac{\kappa}{2}\alpha^2\omega^2.$$

第二步确定可接受的步长范围。与式 (7.14)比较，只要 $-1 + \tfrac{\kappa}{2}\alpha \le -c$，也就是 $\alpha \le 2(1-c)/\kappa$，Armijo 条件就成立。

第三步给出步长下界。若 $\alpha = 1$ 被接受，则 $\alpha = 1 \ge \beta/\kappa$。否则上一个试探值 α/β 被拒绝，必有 $\alpha/\beta > 2(1-c)/\kappa$。由 $c < \tfrac{1}{2}$ 得 $2(1-c) > 1$，所以 $\alpha > \beta/\kappa$。

第四步估计下降量。由式 (7.14)和步长下界，

$$f(\boldsymbol{x}) - f(\boldsymbol{x}^{(t+1)}) \ge c\alpha\omega^2 \ge \frac{c\beta}{\kappa}\omega^2.$$

由 $\boldsymbol{H}^{-1} \succeq L^{-1}\boldsymbol{I}$，有 $\omega^2 \ge \|\boldsymbol{g}\|_2^2 / L$。

第五步用梯度控制目标差。强凸性给出，对任意 $\boldsymbol{y}$，

$$f(\boldsymbol{y}) \ge f(\boldsymbol{x}) + \boldsymbol{g}^\top(\boldsymbol{y} - \boldsymbol{x}) + \frac{\mu}{2}\|\boldsymbol{y} - \boldsymbol{x}\|_2^2 \ge f(\boldsymbol{x}) - \frac{\|\boldsymbol{g}\|_2^2}{2\mu},$$

其中第二个不等号是对 $\boldsymbol{y}$ 取右端的最小值。令 $\boldsymbol{y} = \boldsymbol{x}^\star$，得 $\|\boldsymbol{g}\|_2^2 \ge 2\mu(f(\boldsymbol{x}) - f^\star)$。

综合第四、第五步，

$$f(\boldsymbol{x}) - f(\boldsymbol{x}^{(t+1)}) \ge \frac{c\beta}{\kappa L} \cdot 2\mu\big(f(\boldsymbol{x}) - f^\star\big) = \frac{2c\beta}{\kappa^2}\big(f(\boldsymbol{x}) - f^\star\big).$$

两边减 $f^\star$ 后整理，即得式 (7.16)。 ∎

这个速率含 κ^2，远比实际表现差，而且算法本身不受坐标伸缩的影响，界却依赖坐标下的 μ, L。定理的作用不在于预测步数，而在于保证从任何起点出发目标都稳定下降，梯度趋于零。要得到不依赖坐标的步数界，需要对三阶导数作更细致的假设，证明篇幅较长，读者可查阅[1]。

[1] S. Boyd, L. Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004

完整步何时恢复　全局定理保证迭代进入解的附近，但如果进入后步长仍小于 1，局部二次收敛就得不到。表 7.3显示步长很快回到 1，下面的定理说明这不是偶然。

定理 7.4　完整步的接受与二次收敛　在定理 7.3的条件下，再设 $\nabla^2 f$ 是 M-Lipschitz 的，记

$$\tau = \min\{1,\, 3(1-2c)\}\frac{\mu^2}{M}. \tag{7.17}$$

若 $\|\boldsymbol{g}^{(t)}\|_2 \le \tau$，则 $\alpha = 1$ 通过 Armijo 检验，且

$$\|\boldsymbol{g}^{(t+1)}\|_2 \le \frac{M}{2\mu^2}\|\boldsymbol{g}^{(t)}\|_2^2 \le \frac{1}{2}\|\boldsymbol{g}^{(t)}\|_2. \tag{7.18}$$

因此一旦某轮梯度范数不超过 τ，此后每轮都接受完整步，梯度范数二次收敛到零。

证明　省略上标。令 $h(s) = f(\boldsymbol{x} + s\boldsymbol{d})$。先用 Taylor 公式的积分余项写出

$$h(1) = h(0) + h'(0) + \int_0^1 (1-s)h''(s)\,\mathrm{d}s.$$

这里 $h'(0) = -\omega^2$。由 Hessian 的 Lipschitz 条件，

$$h''(s) = \boldsymbol{d}^{\top}\nabla^2 f(\boldsymbol{x}+s\boldsymbol{d})\boldsymbol{d} \le \omega^2 + Ms\|\boldsymbol{d}\|_2^3.$$

代入积分，得到

$$f(\boldsymbol{x}+\boldsymbol{d}) \le f(\boldsymbol{x}) - \frac{1}{2}\omega^2 + \frac{M}{6}\|\boldsymbol{d}\|_2^3.$$

要通过 Armijo 检验，只需

$$\frac{M}{6}\|\boldsymbol{d}\|_2^3 \le \Big(\frac{1}{2} - c\Big)\omega^2.$$

由 $\|\boldsymbol{d}\|_2^2 \le \omega^2/\mu$，只需 $\|\boldsymbol{d}\|_2 \le 3(1-2c)\mu/M$。而 $\|\boldsymbol{d}\|_2 \le \|\boldsymbol{g}\|_2/\mu$，所以条件 $\|\boldsymbol{g}\|_2 \le 3(1-2c)\mu^2/M$ 足够。

再看新点的梯度。沿线段积分并用 $\boldsymbol{g}+\boldsymbol{H}\boldsymbol{d}=\boldsymbol{0}$，得到

$$\nabla f(\boldsymbol{x}+\boldsymbol{d})=\int_0^1\big(\nabla^2 f(\boldsymbol{x}+s\boldsymbol{d})-\boldsymbol{H}\big)\boldsymbol{d}\,\mathrm{d}s.$$

被积项范数不超过 $Ms\|\boldsymbol{d}\|_2^2$，积分后得到

$$\|\nabla f(\boldsymbol{x}+\boldsymbol{d})\|_2\le\frac{M}{2}\|\boldsymbol{d}\|_2^2\le\frac{M}{2\mu^2}\|\boldsymbol{g}\|_2^2.$$

再由 $\|\boldsymbol{g}\|_2\le\mu^2/M$，得到式 (7.18)的第二个不等号。新点的梯度范数仍不超过 τ，归纳即得结论。 ■

两个定理合起来刻画了整段迭代。在定理 7.3的保证下，目标差趋于零；由 $\|\boldsymbol{g}\|_2^2\le 2L(f(\boldsymbol{x})-f^\star)$，梯度范数在有限步内降到 τ 以下；从此进入完整步阶段，速度由定理 7.4给出。线搜索负责把迭代带到解附近，然后自动退出。

为什么先试 $\alpha=1$，为什么 $c<\frac12$　先试 $\alpha=1$ 不是习惯，而是快速收敛的必要条件。若永远用固定的 $\alpha<1$，在解附近目标接近二次，误差满足 $\boldsymbol{e}^{(t+1)}\approx(1-\alpha)\boldsymbol{e}^{(t)}$，收敛退化为线性。图 7.11(a) 显示，$\alpha=0.9$ 和 $\alpha=0.5$ 都只有直线下降，$\alpha=0.5$ 时误差每步减半。

$c<\frac12$ 同样与完整步有关。在二次目标上，沿 Newton 方向有精确的下降量

$$h(\alpha)-h(0)=-\alpha\omega^2+\frac12\alpha^2\omega^2.$$

取 $\alpha=1$ 得 $-\frac12\omega^2$，Armijo 的右端是 $-c\omega^2$。所以 $c\le\frac12$ 时完整步可接受，$c>\frac12$ 时连精确的模型极小点都被拒绝，如图 7.11(b) 所示。

7.1 Newton 法
7.2 阻尼 Newton 法
7.3 修正 Newton 法
7.4 非精确 Newton 法
7.5 收敛与计算成本
7.6 本章小结

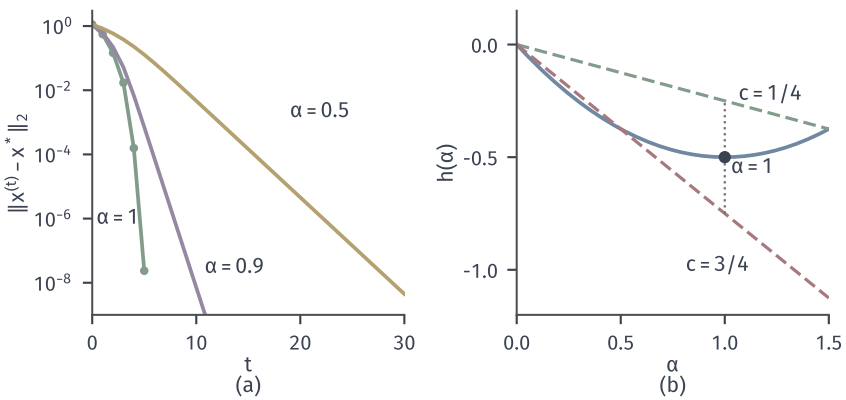


图 7.11 完整步的作用。(a) 目标 (7.4)上从 $(\frac{1}{2}, 0)$ 出发、使用固定步长的距离误差：绿线 $\alpha = 1$，紫线 $\alpha = 0.9$，黄线 $\alpha = 0.5$。(b) 二次目标沿 Newton 方向的变化量 $h(\alpha)$（蓝，取 $\omega^2 = 1$），绿色和红色虚线分别是 $c = \frac{1}{4}$ 和 $c = \frac{3}{4}$ 的 Armijo 线。$\alpha = 1$ 处的黑点在绿线下方、红线上方，所以前者接受、后者拒绝。

回溯只需要函数值，每次试探一次函数计算。Newton 方向的尺度已经带上了曲率信息，试探通常一两次就结束，所以这里用 Armijo 条件就够了。第 5章中要求方向导数的线搜索条件，主要用在方向尺度不明确或曲率更新需要额外保证的方法上。

7.3 修正 Newton 法

上一节假定 Hessian 正定。这就需要回答：Hessian 不定或接近奇异时，方向本身已经不可用，怎样改造曲率矩阵，既得到可靠的下降方向，又不破坏解附近的快速收敛？

缩短步长为什么不够 在目标 (7.4)的点 $\boldsymbol{x} = (-\frac{1}{2}, \frac{3}{4})$ 处，$u = \frac{1}{2}$，由式 (7.5)，

$$\boldsymbol{g} = \begin{bmatrix} -\frac{1}{2} \\ 1 \end{bmatrix}, \qquad \boldsymbol{H} = \begin{bmatrix} 1 & 2 \\ 2 & 2 \end{bmatrix}.$$

$\boldsymbol{H}$ 的行列式是 -2，特征值约为 3.56 和 -0.56，不定。由式 (7.6)，Newton 方向是 $\boldsymbol{d} = (-1.5, 1)$，方向导数为

$$\boldsymbol{g}^{\top}\boldsymbol{d} = 0.75 + 1 = 1.75 > 0.$$

这是上坡方向，无论步长取多小，目标都上升。图 7.14中红色箭头正是这个方向，它指向离解更远的地方。

Hessian 接近奇异时情形相反：方向是下坡的，但 $\|\boldsymbol{d}\|_2$ 大得离谱。上一节 $(-1, \frac{6}{5})$ 处的方向长度超过 22，回溯要试探五次才找到可接受的步长。

问题出在模型的形状。负曲率方向上碗是倒扣的，几乎平坦的方向上碗底远在天边。于是不改步长，改曲率矩阵。

用正定矩阵代替 Hessian　修正 Newton 法（modified Newton method）用一个正定矩阵 $\boldsymbol{B}^{(t)}$ 代替 $\boldsymbol{H}^{(t)}$，解

$$\boldsymbol{B}^{(t)}\boldsymbol{d}^{(t)} = -\boldsymbol{g}^{(t)}, \qquad \boldsymbol{B}^{(t)} = \boldsymbol{H}^{(t)} + \boldsymbol{E}^{(t)} \succ \mathbf{0}. \tag{7.19}$$

其中 $\boldsymbol{E}^{(t)}$ 是修正量。方向导数是

$$(\boldsymbol{g}^{(t)})^{\top}\boldsymbol{d}^{(t)} = -(\boldsymbol{g}^{(t)})^{\top}(\boldsymbol{B}^{(t)})^{-1}\boldsymbol{g}^{(t)}.$$

$\boldsymbol{B}^{(t)}$ 正定，所以只要 $\boldsymbol{g}^{(t)} \neq \mathbf{0}$，方向就是下降方向，上一节的回溯可以照用。

修正量的选择要在两种需求之间平衡。一方面希望 $\boldsymbol{E}^{(t)}$ 足够大，让 $\boldsymbol{B}^{(t)}$ 的条件数不太差。另一方面希望 $\boldsymbol{E}^{(t)}$ 尽量小，因为它越大，模型离真实的曲率越远。Hessian 本来就足够正定时，应当令 $\boldsymbol{E}^{(t)} = \mathbf{0}$。下面三种常见做法，差别在于用什么代价换来多少修正。

对角平移　最简单的修正是取 $\boldsymbol{E}^{(t)} = \delta^{(t)}\boldsymbol{I}$：

$$\boldsymbol{B}^{(t)} = \boldsymbol{H}^{(t)} + \delta^{(t)}\boldsymbol{I}, \qquad \delta^{(t)} > \max\{0, -\lambda_{\min}(\boldsymbol{H}^{(t)})\}. \tag{7.20}$$

所有特征值都加上 $\delta^{(t)}$，特征向量不变。把 $\boldsymbol{g}^{(t)}$ 按 $\boldsymbol{H}^{(t)}$ 的正交特征向量 $\boldsymbol{q}_i$ 展开，方向可以写成

$$\boldsymbol{d}(\delta) = -\sum_{i=1}^{n} \frac{\boldsymbol{q}_i^{\top}\boldsymbol{g}^{(t)}}{\lambda_i + \delta}\boldsymbol{q}_i.$$

从这个式子可以读出 δ 的作用。δ 很小时接近 Newton 方向。δ 远大于所有 $|\lambda_i|$ 时，$\boldsymbol{d}(\delta) \approx -\boldsymbol{g}^{(t)}/\delta$，退化成短的负梯度步。所以 δ 是在 Newton 方向和梯度方向之间连续调节的旋钮，调大它，步子变短，方向转向负梯度。

取 Hessian 正定但接近奇异的点 $(-1, \frac{6}{5})$，特征值约为 0.039 和 10.16。表 7.4列出几个 δ 下的结果，图 7.12(a) 画出长度的变化。δ 越过小特征值 0.039 后，长度迅速下降。$\delta = 1$ 的完整步就把目标从 2.04 降到 1.231，比不修正时好得多；$\delta = 100$ 时几乎不动。

δ	$\boldsymbol{d}(\delta)$	$\|\boldsymbol{d}(\delta)\|_2$	$f(\boldsymbol{x}+\boldsymbol{d}(\delta))$
0	$(10, -20.2)$	22.54	10032
0.1	$(2.881, -5.678)$	6.367	64.66
1	$(0.448, -0.731)$	0.858	1.231
10	$(0.0791, -0.0597)$	0.0991	1.930
100	$(0.0113, -0.0044)$	0.0121	2.025

表 7.4　在 $\boldsymbol{x} = (-1, \frac{6}{5})$ 处对角平移的效果，出发点的目标值是 2.04。修正太小方向过长，修正太大几乎原地不动。

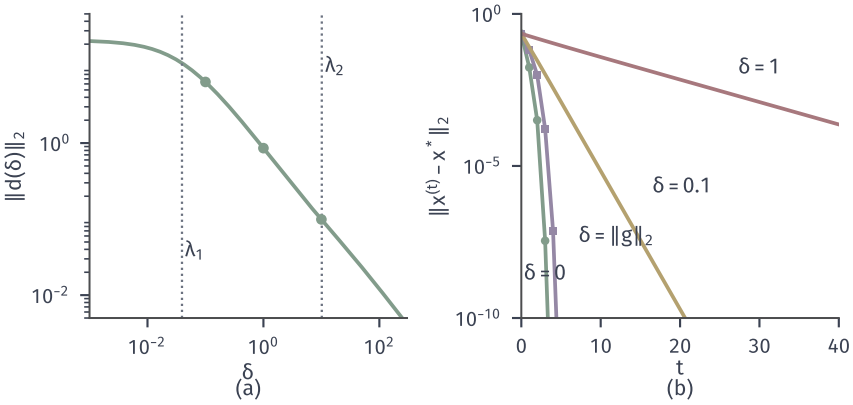


图 7.12　对角平移的两个效应。(a) 在 $(-1, \frac{6}{5})$ 处方向长度随 δ 的变化，灰色竖线是 Hessian 的两个特征值，绿点对应 $\delta = 0.1, 1, 10$。(b) 从 $(0.9, 0.8)$ 出发、使用完整步的距离误差：绿线 $\delta = 0$，紫线 $\delta = \|\boldsymbol{g}\|_2$，黄线 $\delta = 0.1$，红线 $\delta = 1$。修正量不消失时收敛只有线性。

实际上不必先算 $\lambda_{\min}$。尝试对 $\boldsymbol{H}^{(t)} + \delta \boldsymbol{I}$ 作 Cholesky 分解：分解成功说明已经正定，遇到非正主元就增大 δ 再试。这正是后面计算过程采用的做法。

谱修正　对角平移把所有特征值一起抬高，也改动了本来很好的方向。如果能算出谱分解 $\boldsymbol{H}^{(t)} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\top}$，就可以只改有问题的特征值，这称为**谱修正**（spectral modification）：

$$\boldsymbol{B}^{(t)} = \boldsymbol{Q}\tilde{\boldsymbol{\Lambda}}\boldsymbol{Q}^{\top}, \qquad \tilde{\lambda}_i = \max\{|\lambda_i|, \, \epsilon\}. \tag{7.21}$$

其中 $\epsilon > 0$ 是下限。取绝对值的含义是：负曲率方向上，模型的碗是倒扣的，那就翻过来，弯度的大小不变。Newton 方向在这个特征方向上的分量 $-\boldsymbol{q}_i^{\top}\boldsymbol{g}/\lambda_i$ 指向鞍点，翻转后变为 $-\boldsymbol{q}_i^{\top}\boldsymbol{g}/|\lambda_i|$，朝下坡方向走。

图 7.13比较三种常见的特征值映射。只把小于下限的值截到 ϵ 也是一种选择，但在负曲率方向上会得到很大的步。在 $(-\frac{1}{2}, \frac{3}{4})$ 处，取 $\epsilon = 0.1$ 的截

断规则给出的方向是 $(7.87, -6.32)$，比取绝对值得到的 $(1.33, -1.21)$ 长了好几倍。

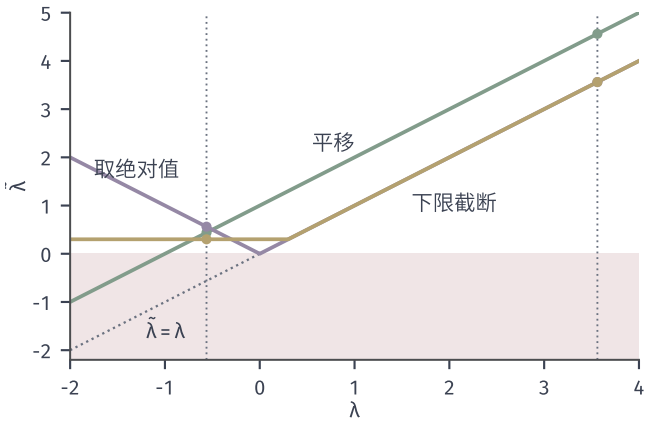


图 7.13 特征值 λ 经修正后的值 $\tilde{\lambda}$。绿线是平移 $\delta = 1$，紫线是取绝对值，黄线是下限截断 $\max\{\lambda, 0.3\}$，灰色点线是不修正。竖线标出 $(-\frac{1}{2}, \frac{3}{4})$ 处 Hessian 的两个特征值，三条线上的点是修正后的值。红色浅底是不允许的非正区域。

谱修正的修正量最贴合问题，但要计算完整的特征分解，稠密时的常数比 Cholesky 分解大得多。

修正 Cholesky 分解 第三种做法把修正放进分解过程。在作 $\boldsymbol{LDL}^\top$ 分解时，第 j 步的主元 c_j 如果太小或为负，就把它换成正数，分解继续往下走。这称为**修正 Cholesky 分解**（modified Cholesky factorization），得到的 $\boldsymbol{B} = \boldsymbol{LDL}^\top$ 自动正定，分解已经完成，成本与普通分解同量级。

在 $(-\frac{1}{2}, \frac{3}{4})$ 处。第一个主元是 $c_1 = 1$，消元乘子是 $\ell_{21} = 2$，第二个主元是

$$c_2 = 2 - \ell_{21}^2 c_1 = 2 - 4 = -2.$$

这个主元为负，普通 Cholesky 分解在此失败。把它换成绝对值 $d_2 = 2$，得到

$$\boldsymbol{B} = \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 2 & 6 \end{bmatrix}.$$

相当于只修改了右下角元素，$\boldsymbol{E} = \operatorname{diag}(0, 4)$。

简单地“遇到负主元就取绝对值”可能带来很大的修正，因为小主元会放大后面的元素。取

$$\boldsymbol{H} = \begin{bmatrix} 0.01 & 1 \\ 1 & 0 \end{bmatrix},$$

它的特征值约为 ± 1，平移量 1 多一点就够。可是 $c_1 = 0.01$ 是正的，不作修改，于是 $\ell_{21} = 100$，$c_2 = 0 - 100^2 \times 0.01 = -100$。取绝对值之后 $\boldsymbol{B}$ 的右下角是 $\ell_{21}^2 c_1 + d_2 = 200$，修正量高达 200。

办法是同时限制消元乘子的大小。记 $\theta_j = \max_{i>j}|c_{ij}|$ 为第 j 列主元下方尚未除以主元的元素的最大绝对值，给定上界 $\bar{\beta} > 0$ 和下限 $\hat{\delta} > 0$，取

$$d_j = \max\Big\{|c_j|,\ \frac{\theta_j^2}{\bar{\beta}^2},\ \hat{\delta}\Big\}. \tag{7.22}$$

上面的例子取 $\bar{\beta} = 1$。第一列 $\theta_1 = 1$，所以 $d_1 = \max\{0.01, 1, \hat{\delta}\} = 1$，$\ell_{21} = 1$。第二个主元是 $c_2 = 0 - 1 = -1$，$d_2 = 1$。最后得到

$$\boldsymbol{B} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}, \qquad \boldsymbol{E} = \operatorname{diag}(0.99,\ 2).$$

修正量降到与 $|\lambda_{\min}|$ 同一量级。参数怎样选择才能在理论上控制 $\|\boldsymbol{E}\|$，证明较长，读者可查阅[2]。

[2] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

三种修正的比较 图 7.14和表 7.5在同一点比较三种修正。三个方向都转向了下坡，都需要回溯一次，$\alpha = 1$ 都被拒绝，$\alpha = \frac{1}{2}$ 都被接受。这一点上修正 Cholesky 分解的新点目标值最低，这只是这一步的结果，不代表它总是更好。

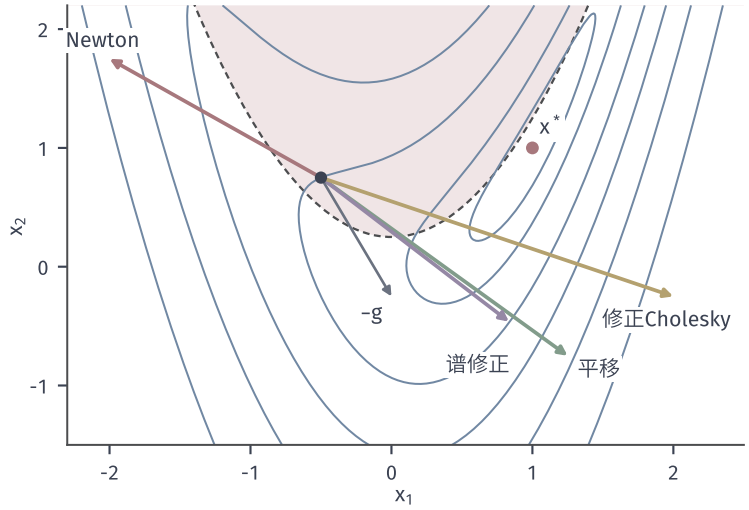


图 7.14 $\boldsymbol{x} = (-\frac{1}{2}, \frac{3}{4})$（黑点）处的几种方向，箭头按实际长度绘制。红色是未修正的 Newton 方向，指向上坡。绿色、紫色、黄色分别是对角平移 $\delta = 1$、谱修正（取绝对值）、修正 Cholesky 分解得到的方向，灰色是负梯度。蓝线是等高线，红色浅底是 Hessian 不定的区域，红点是解。

做法	$\|\boldsymbol{E}\|_2$	$\boldsymbol{d}$	$\boldsymbol{g}^{\top}\boldsymbol{d}$	α	新点 f
对角平移 $\delta=1$	1	$(1.75,-1.5)$	-2.375	$\frac{1}{2}$	0.2151
谱修正（绝对值）	1.123	$(1.334,-1.213)$	-1.880	$\frac{1}{2}$	0.3604
修正 Cholesky	4	$(2.5,-1)$	-2.25	$\frac{1}{2}$	0.1289

表 7.5　在 $(-\frac{1}{2},\frac{3}{4})$ 处三种修正的结果，出发点目标值 1.375，回溯参数 $c=0.1$，$\beta=0.5$。

计算过程　下面以对角平移为例写出完整算法，它只用 Cholesky 分解试探，不需要特征值。δ 的试探规则如下：对角元都为正时从 0 开始试；否则从 $-\min_i h_{ii}+b$ 开始，$b>0$ 是一个固定的基准量；分解失败时令 $\delta\leftarrow\max\{2\delta,b\}$。

变量

- $\boldsymbol{x},\boldsymbol{g},\boldsymbol{H}$：当前点、梯度、Hessian。
- δ：本轮的对角平移量，每轮重新确定。
- $\boldsymbol{L}$：$\boldsymbol{H}+\delta\boldsymbol{I}$ 的 Cholesky 因子。
- $\boldsymbol{d}$：修正后的方向。
- α,c,β：回溯所用的量，与上一节相同。
- b：平移基准量，例中取 1。

初始化　选定 $\boldsymbol{x}^{(0)}$ 和各参数。例中取下面的数据：

$$\boldsymbol{x}^{(0)}=\left(-\tfrac{1}{2},\tfrac{3}{4}\right),\qquad b=1,\qquad c=0.1,\qquad \beta=0.5,\qquad \varepsilon=10^{-6}.$$

每轮更新　在第 t 轮：

1. **读取导数并检查停止**。计算 $\boldsymbol{g}^{(t)}$、$\boldsymbol{H}^{(t)}$，若 $\|\boldsymbol{g}^{(t)}\|_2\le\varepsilon$，输出 $\boldsymbol{x}^{(t)}$ 并结束。

   例中第一轮的数据已在本节开头列出。

2. **确定平移量**。按上述规则试探，直到 Cholesky 分解成功，得到 $\delta^{(t)}$ 和 $\boldsymbol{L}$。

   例中第一轮对角元都为正，先试 $\delta=0$，第二个主元 $2-4=-2$，分解失败。再试 $\delta=1$，矩阵和因子为

$$\boldsymbol{H}+\boldsymbol{I}=\begin{bmatrix}2&2\\2&3\end{bmatrix},\qquad \boldsymbol{L}=\begin{bmatrix}\sqrt{2}&0\\\sqrt{2}&1\end{bmatrix},$$

   分解成功，$\delta^{(0)}=1$。

3. **求方向**。前代、回代解方程 (7.19)。

   例中第一轮解 $2d_1 + 2d_2 = \frac{1}{2}$，$2d_1 + 3d_2 = -1$，得到

$$\boldsymbol{d}^{(0)} = \begin{bmatrix} 1.75 \\ -1.5 \end{bmatrix}.$$

4. **回溯并更新**。从 $\alpha = 1$ 开始按式 (7.14)回溯，然后更新 $\boldsymbol{x}$，令 $t \leftarrow t+1$。

   例中第一轮方向导数为 -2.375。试 $\alpha = 1$，新点目标值 5.379，高于右端 1.1375，拒绝。试 $\alpha = \frac{1}{2}$，新点是 $(\frac{3}{8}, 0)$，目标值 0.2151，低于右端 1.2563，接受。

   第二轮 $u = -\frac{9}{64}$，$1 - 4u = \frac{25}{16} > 0$，Hessian 已经正定，$\delta^{(1)} = 0$ 的分解成功。方向就是 Newton 方向，由式 (7.6)，

$$d_1 = \frac{5/8}{25/16} = \frac{2}{5}, \qquad d_2 = \frac{9}{64} + \frac{3}{4}\cdot\frac{2}{5} = 0.440625.$$

   完整步被接受，到达 $(0.775, 0.440625)$，目标值 0.0509。

各轮结果见表 7.6。修正只在第一轮出现，第 6 轮梯度范数低于容差，迭代结束，最终得到 $\boldsymbol{x}^{(6)} \approx (1,1)$。图 7.15是这条路径。

t	$\boldsymbol{x}^{(t)}$	f	$\delta^{(t)}$	$\alpha^{(t)}$
0	$(-0.5, 0.75)$	1.375	1	1/2
1	$(0.375, 0)$	0.2151	0	1
2	$(0.775, 0.4406)$	0.05091	0	1
3	$(0.9122, 0.8133)$	4.21e−3	0	1
4	$(0.9939, 0.9811)$	6.34e−5	0	1
5	$(0.99984, 0.99965)$	1.40e−8	0	1
6	$(1.0000, 1.0000)$	9.1e−16	停止	

表 7.6　对角平移的修正 Newton 法从 $(-\frac{1}{2}, \frac{3}{4})$ 出发的迭代，只有第一轮需要修正和回溯。

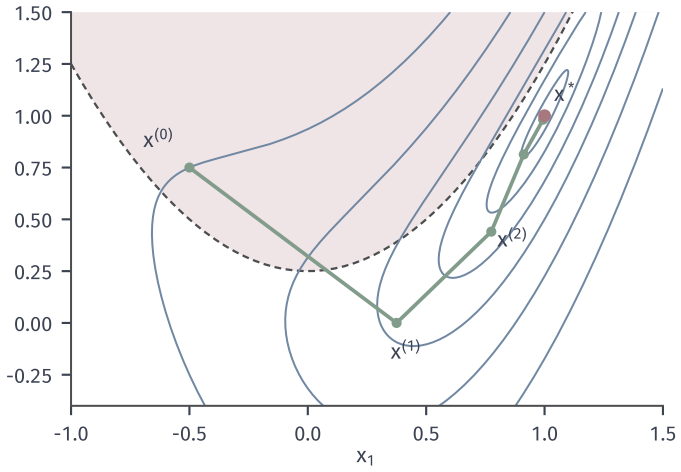


图 7.15 修正 Newton 法的路径（绿）。起点 $(-\frac{1}{2}, \frac{3}{4})$ 在 Hessian 不定的红色浅底区域内，第一步用 $\delta = 1$ 的修正方向并取步长 $\frac{1}{2}$，落入正定区域后修正消失，以后都是完整的 Newton 步。蓝线是等高线，红点是解。

全局性质：一致有界的修正 修正之后方向不再是 Newton 方向，上一节的定理不能直接用。下面的结论只要求修正后的矩阵特征值一致有界，不要求目标凸，这正是修正要达到的目的。

定理 7.5 修正方向的全局收敛 设 f 有下界，∇f 是 L-Lipschitz 的，存在 $0 < b \le \bar{b}$，使各轮 $b\boldsymbol{I} \preceq \boldsymbol{B}^{(t)} \preceq \bar{b}\boldsymbol{I}$。方向由方程 (7.19)给出，步长由 Armijo 回溯确定，$c \in (0,1)$，$\beta \in (0,1)$，初始试探为 1。记

$$\alpha_{\min} = \min\Big\{1,\ \frac{2\beta(1-c)b^2}{L\bar{b}}\Big\}. \tag{7.23}$$

则

$$\min_{0 \le t \le T} \|\boldsymbol{g}^{(t)}\|_2^2 \le \frac{\bar{b}\,\big(f(\boldsymbol{x}^{(0)}) - \inf f\big)}{c\,\alpha_{\min}\,(T+1)}. \tag{7.24}$$

特别地，$\|\boldsymbol{g}^{(t)}\|_2 \to 0$。

证明 省略上标。梯度 L-Lipschitz 给出二次上界

$$f(\boldsymbol{x} + \alpha\boldsymbol{d}) \le f(\boldsymbol{x}) + \alpha \boldsymbol{g}^{\top}\boldsymbol{d} + \frac{L}{2}\alpha^2 \|\boldsymbol{d}\|_2^2.$$

与 Armijo 条件比较，只要

$$\alpha \le \frac{2(1-c)|\boldsymbol{g}^{\top}\boldsymbol{d}|}{L\|\boldsymbol{d}\|_2^2},$$

条件就成立。

由特征值的界，方向导数和方向长度满足

$$|\boldsymbol{g}^{\top}\boldsymbol{d}| = \boldsymbol{g}^{\top}\boldsymbol{B}^{-1}\boldsymbol{g} \geq \frac{\|\boldsymbol{g}\|_2^2}{\bar{b}}, \qquad \|\boldsymbol{d}\|_2 \leq \frac{\|\boldsymbol{g}\|_2}{b}.$$

于是上述门槛不小于 $2(1-c)b^2/(L\bar{b})$。回溯的步长要么是初始的 1，要么是一个被拒绝的值乘以 β，所以 $\alpha \geq \alpha_{\min}$。

代入 Armijo 条件，每轮下降量满足

$$f(\boldsymbol{x}) - f(\boldsymbol{x}^{(t+1)}) \geq c\,\alpha_{\min}\frac{\|\boldsymbol{g}\|_2^2}{\bar{b}}.$$

对 $t = 0, \dots, T$ 求和，左端不超过 $f(\boldsymbol{x}^{(0)}) - \inf f$，最小值不超过平均值，即得式 (7.24)。由于级数 $\sum_t \|\boldsymbol{g}^{(t)}\|_2^2$ 收敛，通项趋于零。 ■

结论只说梯度趋于零，极限点可能是鞍点。在鞍点处 $\boldsymbol{g}^{(t)} = \boldsymbol{0}$，方程 (7.19)的解是零向量，无论怎样修正都不会动。怎样从鞍点离开，是第 10章的问题。

修正何时消失 修正对局部速度的影响可以精确写出来。设 $\boldsymbol{e} = \boldsymbol{x}^{(t)} - \boldsymbol{x}^{\star}$，$\boldsymbol{B} = \boldsymbol{H}^{(t)} + \boldsymbol{E}$，步长为 1。照定理 7.2证明的做法，得到

$$\boldsymbol{x}^{(t+1)} - \boldsymbol{x}^{\star} = \boldsymbol{B}^{-1}\Big[\int_0^1 \big(\boldsymbol{H}^{(t)} - \nabla^2 f(\boldsymbol{x}^{\star} + s\boldsymbol{e})\big)\boldsymbol{e}\,\mathrm{d}s + \boldsymbol{E}\boldsymbol{e}\Big].$$

方括号中第一项是模型的二次误差，第二项是修正带来的一次误差。若 $\|\boldsymbol{B}^{-1}\|_2$ 一致有界，就得到

$$\|\boldsymbol{x}^{(t+1)} - \boldsymbol{x}^{\star}\|_2 \leq \|\boldsymbol{B}^{-1}\|_2\Big(\frac{M}{2}\|\boldsymbol{e}\|_2^2 + \|\boldsymbol{E}\|_2\|\boldsymbol{e}\|_2\Big). \tag{7.25}$$

由此可以逐条读出修正的三种结局。若 $\boldsymbol{E}$ 有限步后为零，则恢复二次收敛。若修正量趋于零，收敛是超线性的。若修正量与误差同阶，仍然是二次收敛。修正量不消失时只有线性收敛：在特征值为 λ 的方向上，$\boldsymbol{E} = \delta\boldsymbol{I}$ 的误差因子是 $\delta/(\lambda+\delta)$。

主例解处的小特征值约为 0.185。取 $\delta = 0.1$ 时因子约 0.35，取 $\delta = 1$ 时约 0.84，图 7.12(b) 中黄线和红线的斜率正是如此。紫线取 $\delta = \|\boldsymbol{g}\|_2$，修正量随误差同阶消失，仍然以二次速度收敛。

所以修正 Newton 法必须满足一个要求：Hessian 足够正定时要退回不修正。上面的试探规则总是先试 $\delta = 0$，正好满足这一点。若 $\nabla^2 f(\boldsymbol{x}^{\star}) \succ \boldsymbol{0}$，在解附近分解一次成功，迭代就成为纯粹的 Newton 法。使用谱修正时，下限 ϵ 要小于 $\lambda_{\min}(\nabla^2 f(\boldsymbol{x}^{\star}))$，否则修正不会消失。

7.1 Newton 法
7.2 阻尼 Newton 法
7.3 修正 Newton 法
7.4 非精确 Newton 法
7.4.1 内层精度的控制
7.4.2 Newton-CG
7.5 收敛与计算成本
7.6 本章小结

改迭代与改目标 把 $\boldsymbol{H}^{(t)}$ 换成 $\boldsymbol{H}^{(t)}+\delta\boldsymbol{I}$，方程很像给目标加了正则项 $\frac{\delta}{2}\|\boldsymbol{x}\|_2^2$ 之后的 Newton 方程，两件事却完全不同。下面用一元目标 $f(x)=\frac{1}{2}(x-1)^2$ 比较。

修正迭代时，$x^{(t+1)}=x^{(t)}-(x^{(t)}-1)/(1+\delta)$，极限仍是 1，只是收敛变慢。改目标时，新目标的最小点是 $1/(1+\delta)$，解已经变了。

	修正迭代	改变目标
方程右端	原梯度 $-\boldsymbol{g}^{(t)}$	新目标的梯度 $-\boldsymbol{g}^{(t)}-\delta\boldsymbol{x}^{(t)}$
驻点	与原目标相同	通常移动
作用	让方向可用	改变要解的问题

表 7.7 曲率修正和正则化的区别。修正只影响路径，不影响梯度为零的点。

平移量 δ 还可以根据模型预测准不准来自动调整，这与直接限制位移的长度密切相关，将在第 9章讨论。

7.4 非精确 Newton 法

前面三节都假定方程能精确解出。当 n 很大、完整的 Hessian 存不下或分解不起时，线性方程只解到什么程度就够了，这样做对收敛速度有什么影响？

一个直观的想法是：Newton 方程本身只是对原问题的局部近似，离解远的时候，把这个近似方程解到机器精度并没有意义。比如 $n=10^5$ 的稠密 Hessian 要存 10^{10} 个数，分解一次要约 3×10^{14} 次运算。如果迭代法几十次矩阵向量乘积就能给出足够好的方向，就没有必要付出这个代价。

7.4.1 内层精度的控制

用残差规定精度 设内层算法给出的方向是 $\boldsymbol{d}^{(t)}$。它对 Newton 方程的满足程度用残差来衡量：

$$\boldsymbol{r}^{(t)}=\boldsymbol{H}^{(t)}\boldsymbol{d}^{(t)}+\boldsymbol{g}^{(t)}. \tag{7.26}$$

非精确 Newton 法（inexact Newton method）不要求 $\boldsymbol{r}^{(t)}=\boldsymbol{0}$，只要求残差相对于梯度足够小：

$$\|\boldsymbol{H}^{(t)}\boldsymbol{d}^{(t)}+\boldsymbol{g}^{(t)}\|_2\le\eta_t\|\boldsymbol{g}^{(t)}\|_2, \tag{7.27}$$

其中 $\eta_t\in[0,1)$ 称为**误差比例**（forcing term）。零向量的残差就是 $\boldsymbol{g}^{(t)}$，对应比例 1，所以 $\eta_t<1$ 表示“至少比什么都不做强一点”。$\eta_t=0$ 就是精确的 Newton 法。

用比例而不用绝对容差，是因为要求应当随迭代变化。梯度大时方程的右端大，粗略的解就够了；梯度小时，同样的相对精度自动要求更小的绝对误差。

比例要多小：一个局部定理 和定理 7.2一样，这里需要解附近的非退化和 Hessian 的 Lipschitz 条件。这次用 $\boldsymbol{A}=\nabla^2 f(\boldsymbol{x}^\star)$ 加权的误差 $\|\boldsymbol{A}\boldsymbol{e}\|_2$ 来度量。在解附近，$\boldsymbol{g}\approx\boldsymbol{A}\boldsymbol{e}$，所以这个量就是一阶近似下的梯度范数，与条件 (7.27)用的是同一把尺子。

定理 7.6　非精确 Newton 法的局部收敛　设 f 在开球 $\|\boldsymbol{x}-\boldsymbol{x}^\star\|_2<r$ 上二阶连续可微，$\nabla f(\boldsymbol{x}^\star)=\boldsymbol{0}$，$\boldsymbol{A}=\nabla^2 f(\boldsymbol{x}^\star)\succeq\mu\boldsymbol{I}$，$\mu>0$，Hessian 是 M-Lipschitz 的。记 $\boldsymbol{e}^{(t)}=\boldsymbol{x}^{(t)}-\boldsymbol{x}^\star$，以及

$$s_t=\|\boldsymbol{A}\boldsymbol{e}^{(t)}\|_2,\qquad \rho_t=\frac{M s_t}{\mu^2}. \tag{7.28}$$

若 $s_t<\min\{\mu r,\ \mu^2/(2M)\}$，$\eta_t\in[0,1]$，$\boldsymbol{d}^{(t)}$ 满足条件 (7.27)，$\boldsymbol{x}^{(t+1)}=\boldsymbol{x}^{(t)}+\boldsymbol{d}^{(t)}$，则

$$s_{t+1}\le(1+2\rho_t)(\eta_t+\rho_t)\,s_t. \tag{7.29}$$

证明　省略上标，记 $\boldsymbol{e}=\boldsymbol{e}^{(t)}$，$s=s_t$，$\rho=\rho_t$，$\boldsymbol{H}=\boldsymbol{H}^{(t)}$。

第一步是准备。由 $\boldsymbol{A}\succeq\mu\boldsymbol{I}$ 得 $\|\boldsymbol{e}\|_2\le s/\mu$，因此点在球内，并且 $\|\boldsymbol{e}\|_2<\mu/(2M)$。由 Hessian 的 Lipschitz 条件，

$$\|\boldsymbol{H}-\boldsymbol{A}\|_2\le M\|\boldsymbol{e}\|_2\le\frac{\mu}{2},\qquad \|\boldsymbol{H}^{-1}\|_2\le\frac{2}{\mu}.$$

第二步把梯度写成线性部分加小量。沿线段积分，$\boldsymbol{g}=\boldsymbol{A}\boldsymbol{e}+\boldsymbol{q}_1$，其中

$$\boldsymbol{q}_1=\int_0^1\big(\nabla^2 f(\boldsymbol{x}^\star+\sigma\boldsymbol{e})-\boldsymbol{A}\big)\boldsymbol{e}\,\mathrm{d}\sigma,\qquad \|\boldsymbol{q}_1\|_2\le\frac{M}{2}\|\boldsymbol{e}\|_2^2\le\frac{\rho s}{2}.$$

最后一步用了 $\|\boldsymbol{e}\|_2\le s/\mu$ 和 ρ 的定义。于是残差的界是

$$\|\boldsymbol{r}\|_2\le\eta\|\boldsymbol{g}\|_2\le\eta\Big(1+\frac{\rho}{2}\Big)s.$$

第三步写出新误差。由 $\boldsymbol{d}=\boldsymbol{H}^{-1}(\boldsymbol{r}-\boldsymbol{g})$，

$$\boldsymbol{e}+\boldsymbol{d}=\boldsymbol{H}^{-1}(\boldsymbol{r}+\boldsymbol{q}_2),\qquad \boldsymbol{q}_2=\boldsymbol{H}\boldsymbol{e}-\boldsymbol{g}.$$

与定理 7.2证明中的积分相同，

$$\|\boldsymbol{q}_2\|_2 \le \frac{M}{2}\|\boldsymbol{e}\|_2^2 \le \frac{\rho s}{2}.$$

第四步转到加权误差。在 $\boldsymbol{e}+\boldsymbol{d}$ 上左乘 $\boldsymbol{A}$，并把 $\boldsymbol{A}$ 写成 $\boldsymbol{H}+(\boldsymbol{A}-\boldsymbol{H})$，得到

$$\boldsymbol{A}(\boldsymbol{e}+\boldsymbol{d}) = \big(\boldsymbol{I} + (\boldsymbol{A}-\boldsymbol{H})\boldsymbol{H}^{-1}\big)(\boldsymbol{r}+\boldsymbol{q}_2).$$

括号中第一个因子的范数不超过 $1 + M\|\boldsymbol{e}\|_2 \cdot 2/\mu \le 1 + 2\rho$。第二个因子的范数不超过

$$\eta\Big(1+\frac{\rho}{2}\Big)s + \frac{\rho s}{2} \le (\eta+\rho)s,$$

这里用了 $\eta \le 1$。两者相乘即得式 (7.29)。 ■

式 (7.29)把收缩比拆成两部分：η_t 来自线性方程的残差，ρ_t 来自 Taylor 误差。由此读出三种情形。

第一种，$\eta_t \le \bar{\eta} < 1$。取 $\bar{\rho} \in (0, \tfrac{1}{2}]$ 足够小，使 $(1+2\bar{\rho})(\bar{\eta}+\bar{\rho}) = \bar{\theta} < 1$。只要起始的 s_0 足够小，使 $\rho_0 \le \bar{\rho}$，s_t 就逐步减小，并且

$$s_{t+1} \le \bar{\theta}\, s_t.$$

这是线性收敛，收缩比接近 $\bar{\eta}$。

第二种，$\eta_t \to 0$。此时 $s_t \to 0$，$\rho_t \to 0$，于是

$$\frac{s_{t+1}}{s_t} \le (1+2\rho_t)(\eta_t+\rho_t) \to 0.$$

比值趋于零的收敛称为**超线性收敛**（superlinear convergence）。

第三种，$\eta_t \le C\|\boldsymbol{g}^{(t)}\|_2$。由第二步和 $\rho_t \le \tfrac{1}{2}$，

$$\|\boldsymbol{g}^{(t)}\|_2 \le \Big(1+\frac{\rho_t}{2}\Big)s_t \le \frac{5}{4}s_t.$$

代入式 (7.29)，利用 $1+2\rho_t \le 2$，得到

$$s_{t+1} \le 2\Big(\frac{5}{4}C + \frac{M}{\mu^2}\Big)s_t^2.$$

这是二次收敛。一般地，$\eta_t \le C\|\boldsymbol{g}^{(t)}\|_2^{\theta}$（$0 < \theta \le 1$）给出 $1+\theta$ 阶收敛。

实际中常用的比例是

$$\eta_t = \min\{0.5, \sqrt{\|\boldsymbol{g}^{(t)}\|_2}\} \quad \text{或} \quad \eta_t = \min\{0.5, \|\boldsymbol{g}^{(t)}\|_2\}. \tag{7.30}$$

前者是超线性收敛，后者是二次收敛[3]。这样远离解时内层只做很少的工

作，接近解时才逐步加严，避免把精力浪费在一个并不准确的模型上。

图 7.16在目标 (7.4)上验证这些结论。为了让残差比例恰好等于 η_t，这里取 $\boldsymbol{r}^{(t)} = \eta_t \boldsymbol{g}^{(t)}$，此时方向等于 $(1-\eta_t)$ 倍的 Newton 方向。比例取常数时，收缩比稳定在该常数附近；比例趋于零时收缩比也趋于零。

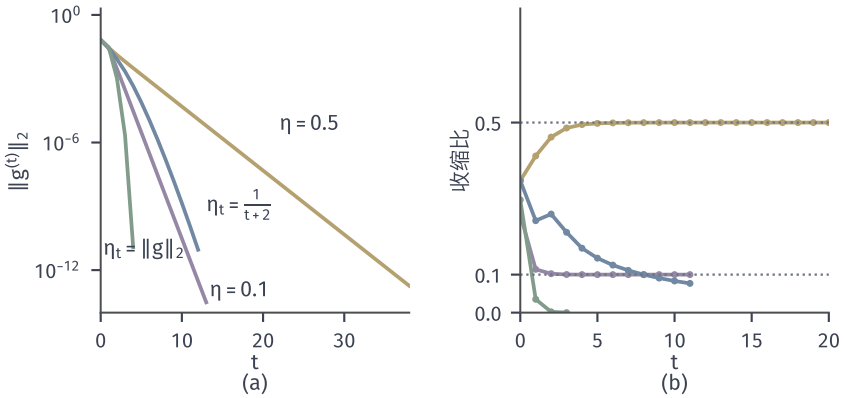


图 7.16　误差比例对局部速度的影响，从 $(0.9, 0.8)$ 出发，残差取 $\eta_t \boldsymbol{g}^{(t)}$。(a) 梯度范数：黄线 $\eta = 0.5$、紫线 $\eta = 0.1$ 是直线，蓝线 $\eta_t = 1/(t+2)$ 越来越陡，绿线 $\eta_t = \|\boldsymbol{g}^{(t)}\|_2$ 几步到底。(b) 各线的收缩比 $\|\boldsymbol{A}\boldsymbol{e}^{(t+1)}\|_2 / \|\boldsymbol{A}\boldsymbol{e}^{(t)}\|_2$，灰色点线标出 0.5 和 0.1。

远离解时　局部定理只说解附近。在远处，条件 (7.27)本身甚至不保证方向下降。把 $\boldsymbol{d} = \boldsymbol{H}^{-1}(\boldsymbol{r} - \boldsymbol{g})$ 代入方向导数，得到

$$\boldsymbol{g}^{\top}\boldsymbol{d} = -\boldsymbol{g}^{\top}\boldsymbol{H}^{-1}\boldsymbol{g} + \boldsymbol{g}^{\top}\boldsymbol{H}^{-1}\boldsymbol{r}.$$

第二项的大小可以超过第一项。设 $\boldsymbol{H}$ 正定，比较两项的界，能够保证方向导数为负的充分条件是 $\eta_t < 1/\kappa(\boldsymbol{H})$，这在病态时非常苛刻。

具体的例子如下。取

$$\boldsymbol{H} = \operatorname{diag}(1, 100), \qquad \boldsymbol{g} = (1, 10).$$

Newton 方向是 $\boldsymbol{d}_{\mathrm{N}} = (-1, -0.1)$。取残差 $\boldsymbol{r} = (2.5, 0.25)$，比例为

$$\frac{\|\boldsymbol{r}\|_2}{\|\boldsymbol{g}\|_2} = \frac{2.5125}{10.050} = 0.25.$$

对应的方向是

$$\boldsymbol{d} = \boldsymbol{H}^{-1}(\boldsymbol{r} - \boldsymbol{g}) = (1.5, -0.0975).$$

它的方向导数是 $\boldsymbol{g}^{\top}\boldsymbol{d} = 1.5 - 0.975 = 0.525 > 0$，满足残差条件，却是上坡方向。

7.1 Newton 法
7.2 阻尼 Newton 法
7.3 修正 Newton 法
7.4 非精确 Newton 法
7.4.1 内层精度的控制
7.4.2 Newton-CG
7.5 收敛与计算成本
7.6 本章小结

图 7.17说明了原因。满足条件的方向构成以 $\boldsymbol{d}_{\mathrm{N}}$ 为中心的椭球，半轴长度正比于 $\eta\|\boldsymbol{g}\|_2/\lambda_i$。Hessian 的小特征值方向上半轴很长，椭球可以越过 $\boldsymbol{g}^{\top}\boldsymbol{d}=0$ 的分界面。

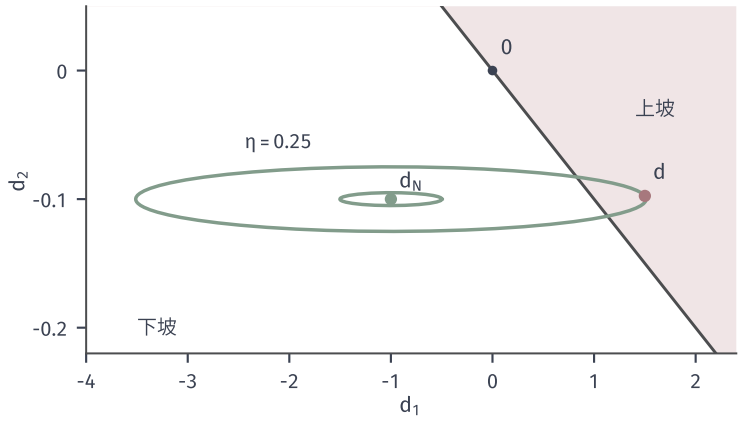


图 7.17　方向空间中满足残差条件的集合，$\boldsymbol{H}=\mathrm{diag}(1,100)$，$\boldsymbol{g}=(1,10)$，注意两轴比例不同。绿色椭圆分别是 $\eta=0.25$ 和 $\eta=0.05$ 的边界，绿点是 Newton 方向，深灰色粗线是 $\boldsymbol{g}^{\top}\boldsymbol{d}=0$，红色浅底是上坡方向的区域。红点 $\boldsymbol{d}$ 的残差比例为 0.25，却落在上坡区域内。

因此远离解时还需要两样东西：内层算法要能保证给出下降方向，外层仍然要作线搜索。一般的迭代线性求解器并不提供前者，下一小节的共轭梯度法却恰好能提供。

7.4.2 Newton-CG

主要思想　Newton 方程的系数矩阵对称，在解附近还正定，最自然的内层算法是共轭梯度法，这种组合称为Newton-CG（Newton conjugate gradient method）。它的吸引力在于，内层只需要能计算 $\boldsymbol{H}^{(t)}$ 乘向量，完全不必形成矩阵。

共轭梯度法的完整推导可参考卷二第 15 章“Krylov 子空间法”，这里只复述用到的结论。为了和式 (7.26)保持一致，把残差定义成 $\boldsymbol{r}_j=\boldsymbol{H}\boldsymbol{z}_j+\boldsymbol{g}$。从 $\boldsymbol{z}_0=\boldsymbol{0}$，$\boldsymbol{r}_0=\boldsymbol{g}$，$\boldsymbol{p}_0=-\boldsymbol{g}$ 出发，第 j 步计算

$$\alpha_j=\frac{\boldsymbol{r}_j^{\top}\boldsymbol{r}_j}{\boldsymbol{p}_j^{\top}\boldsymbol{H}\boldsymbol{p}_j},\qquad \boldsymbol{z}_{j+1}=\boldsymbol{z}_j+\alpha_j\boldsymbol{p}_j,\qquad \boldsymbol{r}_{j+1}=\boldsymbol{r}_j+\alpha_j\boldsymbol{H}\boldsymbol{p}_j,\tag{7.31}$$

$$\beta_j=\frac{\boldsymbol{r}_{j+1}^{\top}\boldsymbol{r}_{j+1}}{\boldsymbol{r}_j^{\top}\boldsymbol{r}_j},\qquad \boldsymbol{p}_{j+1}=-\boldsymbol{r}_{j+1}+\beta_j\boldsymbol{p}_j.\tag{7.32}$$

这里 α_j 沿 $\boldsymbol{p}_j$ 精确极小化模型，每步新的残差与之前的方向正交，新的方向与之前的方向关于 $\boldsymbol{H}$ 共轭。

Hessian 向量积 式 (7.31)中对 $\boldsymbol{H}$ 的唯一需求是计算乘积 $\boldsymbol{H}\boldsymbol{v}$，称为Hessian 向量积（Hessian-vector product）。它是梯度沿 $\boldsymbol{v}$ 的方向导数，所以有三种取得的办法。

第一种是直接公式。对目标 (7.4)，由式 (7.5)，

$$\boldsymbol{H}\boldsymbol{v} = \begin{bmatrix} (1 - 4u + 8x_1^2)v_1 - 4x_1 v_2 \\ -4x_1 v_1 + 2v_2 \end{bmatrix}.$$

只用几次标量运算，不需要存矩阵。

第二种是差分近似，只调用两次梯度：

$$\boldsymbol{H}\boldsymbol{v} \approx \frac{\nabla f(\boldsymbol{x} + h\boldsymbol{v}) - \nabla f(\boldsymbol{x})}{h}. \tag{7.33}$$

误差约与 h 成正比。h 太小时舍入误差又会放大，通常取 h 约为机器精度的平方根除以 $\|\boldsymbol{v}\|_2$ 的量级。

第三种是自动微分，可以精确得到 $\boldsymbol{H}\boldsymbol{v}$，代价是梯度计算的常数倍。无论哪一种，一次乘积的成本都与一次梯度同量级。

CG 产生的方向总是下降的 共轭梯度法有一个一般线性求解器没有的性质：只要迄今各步的曲率都为正，它的每个迭代 $\boldsymbol{z}_j$（$j \geq 1$）都是下降方向，而且这一点不依赖 η_t。

引理 7.7　CG 迭代的下降性　设 $\boldsymbol{g} \neq \boldsymbol{0}$，CG 运行到第 $j \geq 1$ 步，且 $\boldsymbol{p}_i^{\top}\boldsymbol{H}\boldsymbol{p}_i > 0$（$i < j$）。则

$$\boldsymbol{g}^{\top}\boldsymbol{z}_j = -\sum_{i=0}^{j-1} \alpha_i \boldsymbol{r}_i^{\top}\boldsymbol{r}_i < 0. \tag{7.34}$$

证明　由 $\boldsymbol{z}_j = \sum_{i<j} \alpha_i \boldsymbol{p}_i$，只需计算 $\boldsymbol{g}^{\top}\boldsymbol{p}_i$。残差的递推给出 $\boldsymbol{r}_i = \boldsymbol{g} + \boldsymbol{H}\sum_{k<i} \alpha_k \boldsymbol{p}_k$，而 $\boldsymbol{p}_i$ 与之前的方向关于 $\boldsymbol{H}$ 共轭，所以

$$\boldsymbol{g}^{\top}\boldsymbol{p}_i = \boldsymbol{r}_i^{\top}\boldsymbol{p}_i.$$

再由式 (7.32)和 $\boldsymbol{r}_i$ 与 $\boldsymbol{p}_{i-1}$ 正交，

$$\boldsymbol{r}_i^{\top}\boldsymbol{p}_i = -\boldsymbol{r}_i^{\top}\boldsymbol{r}_i.$$

上述正交和共轭关系只依赖算法的代数恒等式，在各步曲率非零时成立，不需要 $\boldsymbol{H}$ 整体正定。代回去，再由 $\alpha_i > 0$ 和 $\boldsymbol{r}_0 = \boldsymbol{g} \neq \boldsymbol{0}$，即得结论。 ■

遇到非正曲率　在式 (7.31)中，$\boldsymbol{p}_j^{\top}\boldsymbol{H}\boldsymbol{p}_j \le 0$ 说明 $\boldsymbol{H}$ 不是正定的，模型沿这个方向无下界，α_j 的公式失去意义。此时内层必须结束。常用的规则是，给定很小的 $\epsilon \ge 0$，当曲率不超过 $\epsilon\|\boldsymbol{p}_j\|_2^2$ 时：

$$\boldsymbol{d}^{(t)} = \begin{cases} -\boldsymbol{g}^{(t)}, & j = 0, \\ \boldsymbol{z}_j, & j \ge 1. \end{cases} \tag{7.35}$$

第一种情形没有已完成的进展，就退回负梯度。第二种情形返回当前的 $\boldsymbol{z}_j$，由引理 7.7，它是下降方向。

图 7.18把两种情况放在一起。图 (a) 在点 $(\tfrac{1}{2}, 0)$ 处，模型是碗，CG 两步到达 Newton 方向。具体来说，此处 $\boldsymbol{g} = (0, -\tfrac{1}{2})$，第一步的方向和乘积是

$$\boldsymbol{p}_0 = \big(0, \tfrac{1}{2}\big), \qquad \boldsymbol{H}\boldsymbol{p}_0 = (-1, 1).$$

曲率为 $\tfrac{1}{2}$，步长 $\alpha_0 = \tfrac{1}{2}$，第一步得到

$$\boldsymbol{z}_1 = \big(0, \tfrac{1}{4}\big), \qquad \boldsymbol{r}_1 = \big(-\tfrac{1}{2}, 0\big).$$

第二步 $\beta_0 = 1$，方向和乘积是

$$\boldsymbol{p}_1 = \big(\tfrac{1}{2}, \tfrac{1}{2}\big), \qquad \boldsymbol{H}\boldsymbol{p}_1 = (1, 0).$$

曲率仍为 $\tfrac{1}{2}$，步长 $\alpha_1 = \tfrac{1}{2}$，于是

$$\boldsymbol{z}_2 = \big(\tfrac{1}{4}, \tfrac{1}{2}\big), \qquad \boldsymbol{r}_2 = \boldsymbol{0}.$$

这正好是第 7.1节算过的 Newton 方向。

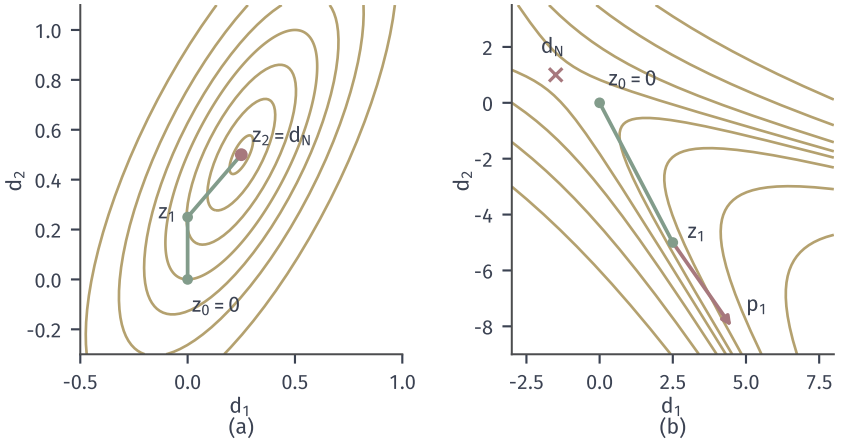


图 7.18　位移空间中的内层共轭梯度，黄线是局部模型的等高线。(a) 在 $(\frac{1}{2}, 0)$ 处模型是碗，绿色折线两步到达红点所示的 Newton 方向。(b) 在 $(-\frac{1}{2}, \frac{3}{4})$ 处模型不定，绿线是第一步，红色箭头 $\boldsymbol{p}_1$（按 0.05 倍绘制）是遇到的负曲率方向，内层在 $\boldsymbol{z}_1$ 处停止；红叉是 Newton 方程的解，它是模型的鞍点。

与非线性共轭梯度的区别　第 6章的非线性共轭梯度法也叫共轭梯度，两者在做不同的事。

	Newton-CG 的内层	非线性共轭梯度法
作用对象	固定的二次模型	原目标
每步信息	一次 $\boldsymbol{Hv}$	梯度和线搜索的函数值
步长	式 (7.31)的闭式公式	线搜索
共轭性	模型上精确（不计舍入）	一般只近似成立
有限步终止	不超过 n 步	没有此结论

表 7.8　二次模型上的线性共轭梯度和直接作用于原目标的非线性共轭梯度。前者是一轮外层迭代中的线性方程求解器。

计算过程　外层和内层的关系见图 7.19。下面用目标 (7.4)从 Hessian 不定的点 $(-\frac{1}{2}, \frac{3}{4})$ 出发。

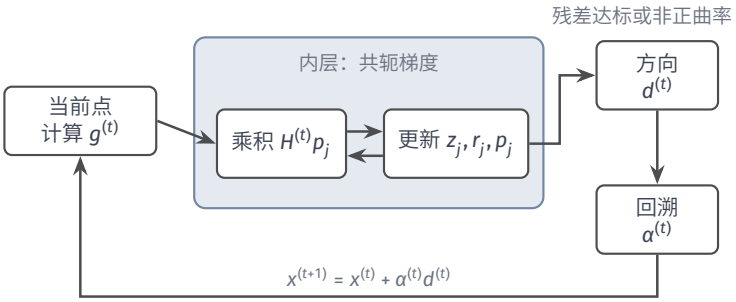


图 7.19　Newton-CG 的结构。外层读取梯度，内层只通过 Hessian 向量积与目标交互，在残差达到式 (7.27)或遇到非正曲率时返回方向 $\boldsymbol{d}^{(t)}$，外层再用回溯确定步长。

变量

- $\boldsymbol{x}, \boldsymbol{g}$：外层的当前点和梯度。
- η_t：本轮的误差比例。
- $\boldsymbol{z}, \boldsymbol{r}, \boldsymbol{p}$：内层的近似解、残差和搜索方向，每轮外层重新初始化。
- $\boldsymbol{q}$：工作向量，存放 $\boldsymbol{H}\boldsymbol{p}$。
- $\boldsymbol{d}, \alpha$：外层方向和步长。
- 不需要 $\boldsymbol{H}$ 的存储，只需要计算 $\boldsymbol{H}\boldsymbol{v}$ 的子程序。

初始化　选定 $\boldsymbol{x}^{(0)}$，c，β，ε。例中初始点和外层容差为

$$\boldsymbol{x}^{(0)} = \left(-\tfrac{1}{2}, \tfrac{3}{4}\right), \qquad c = 0.1, \qquad \beta = 0.5, \qquad \varepsilon = 10^{-6}.$$

误差比例取式 (7.30)中的第一种，曲率阈值取 $\epsilon = 0$。

每轮更新　在第 t 轮外层：

1. **读取梯度并检查停止**。计算 $\boldsymbol{g}^{(t)}$；若 $\|\boldsymbol{g}^{(t)}\|_2 \le \varepsilon$，结束。然后确定 η_t。

   例中第一轮 $\boldsymbol{g}^{(0)} = (-\tfrac{1}{2}, 1)$，$\|\boldsymbol{g}^{(0)}\|_2 = 1.118$，$\eta_0 = 0.5$。

2. **内层初始化**。令 $\boldsymbol{z}_0 = \boldsymbol{0}$，$\boldsymbol{r}_0 = \boldsymbol{g}^{(t)}$，$\boldsymbol{p}_0 = -\boldsymbol{g}^{(t)}$，$j = 0$。

3. **内层迭代**。计算 $\boldsymbol{q} = \boldsymbol{H}^{(t)}\boldsymbol{p}_j$ 及曲率 $\boldsymbol{p}_j^{\top}\boldsymbol{q}$。曲率不超过阈值时按式 (7.35)返回方向。否则按式 (7.31)更新；若 $\boldsymbol{z}_{j+1}$ 已满足条件 (7.27)，就返回它。否则按式 (7.32)更新方向，令 $j \leftarrow j + 1$。

   例中第一轮外层的第一步内层，$\boldsymbol{p}_0 = (\tfrac{1}{2}, -1)$，乘积和曲率为

$$\boldsymbol{q} = \begin{bmatrix} -1.5 \\ -1 \end{bmatrix}, \qquad \boldsymbol{p}_0^{\top}\boldsymbol{q} = 0.25 > 0.$$

步长 $\alpha_0 = 1.25/0.25 = 5$，更新后

$$\boldsymbol{z}_1 = \begin{bmatrix} 2.5 \\ -5 \end{bmatrix}, \qquad \boldsymbol{r}_1 = \begin{bmatrix} -8 \\ -4 \end{bmatrix}.$$

残差比例是 $8.94/1.118 = 8$，大于 η_0，继续。这个比例大于 1，说明模型并不是碗。

第二步内层，$\beta_0 = 80/1.25 = 64$，方向、乘积和曲率为

$$\boldsymbol{p}_1 = \begin{bmatrix} 40 \\ -60 \end{bmatrix}, \qquad \boldsymbol{q} = \begin{bmatrix} -80 \\ -40 \end{bmatrix}, \qquad \boldsymbol{p}_1^{\top}\boldsymbol{q} = -800 < 0.$$

遇到负曲率，由式 (7.35)返回 $\boldsymbol{d}^{(0)} = \boldsymbol{z}_1 = (2.5, -5)$，内层用了 2 次 Hessian 向量积。

4. **回溯并更新**。从 $\alpha = 1$ 开始按式 (7.14)回溯，然后更新 $\boldsymbol{x}$，令 $t \leftarrow t + 1$。

例中第一轮方向导数为 -6.25。$\alpha = 1$ 和 $\frac{1}{2}$ 的目标值分别是 68.56 和 5.379，都被拒绝。$\alpha = \frac{1}{4}$ 的新点是 $(0.125, -0.5)$，目标值 0.6487，低于右端 1.2188，接受。

第二轮 $\boldsymbol{g}^{(1)} = (-0.6172, -1.0313)$，$\|\boldsymbol{g}^{(1)}\|_2 = 1.202$，$\eta_1 = 0.5$，Hessian 为

$$\boldsymbol{H}^{(1)} = \begin{bmatrix} 3.1875 & -0.5 \\ -0.5 & 2 \end{bmatrix}.$$

内层第一步的曲率是 2.7047，$\alpha_0 = 1.4444/2.7047 = 0.5340$，于是

$$\boldsymbol{z}_1 = \begin{bmatrix} 0.3296 \\ 0.5507 \end{bmatrix}, \qquad \boldsymbol{r}_1 = \begin{bmatrix} 0.1581 \\ -0.0946 \end{bmatrix}.$$

残差比例 $0.184/1.202 = 0.153 \le 0.5$，内层结束，只用了一次乘积。完整步被接受。

各轮结果见表 7.9。第 9 轮梯度范数低于容差，迭代结束，最终得到 $\boldsymbol{x}^{(9)} \approx (1, 1)$，整个过程用了 14 次 Hessian 向量积。可以看到比例收紧之前内层大多只走一步，η_t 变小后内层把方程解到精确。

7.1 Newton 法
7.2 阻尼 Newton 法
7.3 修正 Newton 法
7.4 非精确 Newton 法
7.5 收敛与计算成本
7.6 本章小结

t	$\boldsymbol{x}^{(t)}$	f	$\|\boldsymbol{g}^{(t)}\|_2$	η_t	$\boldsymbol{Hv}$ 次数	$\alpha^{(t)}$
0	$(-0.5, 0.75)$	1.375	1.118	0.5	2（负曲率）	1/4
1	$(0.125, -0.5)$	0.6487	1.202	0.5	1	1
2	$(0.4546, 0.0507)$	0.1730	0.407	0.5	1	1
3	$(0.8099, 0.4739)$	0.05121	0.540	0.5	1	1
4	$(0.7596, 0.5197)$	0.03218	0.132	0.364	2	1
5	$(0.9552, 0.8741)$	2.47e−3	0.127	0.356	1	1
6	$(0.9448, 0.8820)$	1.64e−3	0.0260	0.161	2	1
7	$(0.9977, 0.9927)$	1.04e−5	0.0105	0.102	2	1
8	$(0.99998, 0.99995)$	3.43e−10	1.13e−5	0.0034	2	1
9	$(1.0000, 1.0000)$		2.4e−9	停止		

表 7.9　Newton-CG 在目标 (7.4)上的运行，$\eta_t = \min\{0.5, \sqrt{\|\boldsymbol{g}^{(t)}\|_2}\}$。第 0 轮内层因负曲率提前结束。

适用范围与补充　非正曲率规则只保证方向可用，没有利用负曲率本身携带的信息。把遇到的 $\boldsymbol{p}_j$ 当作离开鞍点的方向，或者在一个有限半径的区域内求解模型，分别是第 10章和第 9章的内容。另外，CG 只能看到由 $\boldsymbol{g}^{(t)}$ 生成的 Krylov 子空间；若 $\boldsymbol{g}^{(t)}$ 恰好与某个负曲率方向正交，CG 也察觉不到它。

Hessian 病态时，内层 CG 本身收敛很慢，这时可以预条件，做法与线性方程中的预条件共轭梯度法相同，见前面引用的 Krylov 一章。

7.5 收敛与计算成本

前四节各解决了一个困难。于是要问：在同样的精度要求下，从起点走到终点，这些方法各要花多少计算，局部收敛快是否就意味着总成本低？

统一的比较口径　沿用第 5章的口径：所有方法以 $\|\boldsymbol{g}^{(t)}\|_2 \le \varepsilon$ 为停止标准，返回最后的迭代点，总成本是各轮成本之和。每轮的成本分三部分：读取目标和导数、线性代数运算、线搜索的函数计算。

记一次函数、梯度、Hessian、Hessian 向量积的成本为 c_f, c_g, c_H, c_{Hv}。对稠密问题，c_{Hv} 约为 $2n^2$ 次运算。表 7.10按每轮的成本比较各方法，并把保障分开写。

方法	每轮主要成本	远处的保障	近解行为
Newton 法	c_H，分解 $\frac{1}{3}n^3$	无	二次
阻尼 Newton	上述加回溯的 c_f	正定时下降	接受整步后二次
对角平移	c_H，分解可能重复若干次	$\boldsymbol{g}\to\mathbf{0}$	修正消失后二次
谱修正	c_H，特征分解	$\boldsymbol{g}\to\mathbf{0}$	修正消失后二次
修正 Cholesky	c_H，分解约 $\frac{1}{3}n^3$	$\boldsymbol{g}\to\mathbf{0}$	修正消失后二次
Newton-CG	$k_t c_{Hv}$，无分解	方向下降，回溯	由 η_t 决定

表 7.10　各方法单轮成本和收敛保障的比较，k_t 是第 t 轮内层的 Hessian 向量积次数。“$\boldsymbol{g}\to\mathbf{0}$”需要定理 7.5的条件，“修正消失”要求解处 Hessian 正定且修正规则先试零修正。

两个阶段分开计算　定理 7.3和定理 7.4给出阻尼 Newton 法的总步数上界。取强凸常数 μ、光滑常数 L、Hessian 的 Lipschitz 常数 M 和定理中的阈值 τ。

第一阶段是 $\|\boldsymbol{g}^{(t)}\|_2>\tau$ 的轮次。由定理 7.3证明的第四步，每轮目标至少下降

$$\gamma=\frac{c\beta\tau^2}{\kappa L}.$$

目标总下降量不超过 $f(\boldsymbol{x}^{(0)})-f^\star$，所以这一阶段的轮数不超过 $(f(\boldsymbol{x}^{(0)})-f^\star)/\gamma$。

第二阶段记 $b_t=M\|\boldsymbol{g}^{(t)}\|_2/(2\mu^2)$，由式 (7.18)，$b_{t+1}\le b_t^2$，且起始时 $b\le\frac{1}{2}$。要使 $\|\boldsymbol{g}\|_2\le\varepsilon$，只需 $2^{-2^t}\le M\varepsilon/(2\mu^2)$。于是总步数满足

$$T\le\frac{f(\boldsymbol{x}^{(0)})-f^\star}{\gamma}+\left\lceil\log_2\log_2\frac{2\mu^2}{M\varepsilon}\right\rceil. \tag{7.36}$$

第二项随精度增长极慢：ε 从 10^{-6} 收紧到 10^{-12}，只多大约一步。第一项与 ε 无关，却含有问题常数，通常主导总步数。所以局部收敛阶回答“到了解附近以后怎样”，全局成本回答“总共要花多少”，只看前者不足以判断整体效率。

贵的一步和便宜的很多步　Newton 法每轮贵，轮数少；一阶方法每轮便宜，轮数多。若梯度下降需要 T_{GD} 轮，Newton 法需要 T_{N} 轮，分解成本记为 c_{fac}，则 Newton 法更划算的条件是

$$T_{\mathrm{N}}\bigl(c_g+c_H+c_{\mathrm{fac}}\bigr)<T_{\mathrm{GD}}\,c_g. \tag{7.37}$$

主例从 $(\frac{1}{2},0)$ 出发，把梯度范数降到 10^{-6}，回溯梯度下降用了 245 轮、792 次函数计算，Newton 法用了 5 轮。二维问题的分解几乎不花时间，所以 Newton 法的总成本低得多。

规模变大，结论就可能相反。取稠密 $n = 10^4$，一次 Cholesky 分解约 3.3×10^{11} 次运算，一次梯度若与 n^2 同量级，一次分解约相当于 1700 次矩阵向量乘积。若不到一千次梯度步就能达到要求的精度，Newton 法在稠密实现下就不划算。反过来，Hessian 稀疏时分解可能很便宜，三对角矩阵的分解只需 $O(n)$ 次运算。比较时必须用实际的结构，不能只看 n。

内层的精度也要计入成本　非精确方法的比较要把内层计入。取式 (7.4)的链式推广，$n = 1000$：

$$f(\boldsymbol{x}) = \sum_{i=1}^{n-1} \Big[\frac{1}{2}(x_i - 1)^2 + (x_{i+1} - x_i^2)^2 \Big]. \tag{7.38}$$

从分量交替取 -1.2 和 1 的点出发，用带回溯（$c = 10^{-4}$）的 Newton-CG，把梯度范数降到 10^{-9}。结果列在表 7.11中，图 7.20画出了全过程。

误差比例	外层轮数	$\boldsymbol{Hv}$ 总次数
$\eta = 0.5$	29	93
$\eta = 0.1$	15	72
$\eta_t = \min\{0.5, \sqrt{\lVert \boldsymbol{g}^{(t)} \rVert_2}\}$	17	100
$\eta = 10^{-10}$（近乎精确求解）	12	357

表 7.11　目标 (7.38)上不同误差比例的成本。内层解得越精确，外层轮数越少，总乘积次数却可能大幅增加。

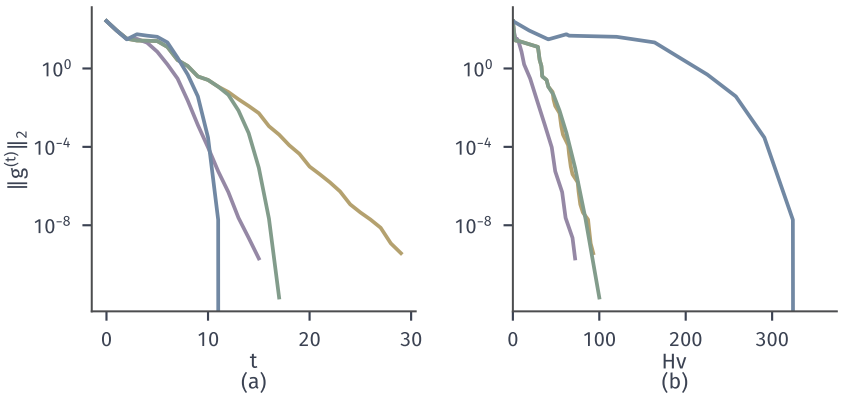


图 7.20　目标 (7.38)上 Newton-CG 的进展，$n = 1000$。(a) 梯度范数随外层轮数 t 的变化，(b) 随累计 Hessian 向量积次数的变化。黄线 $\eta = 0.5$，紫线 $\eta = 0.1$，绿线 $\eta_t = \min\{0.5, \sqrt{\lVert \boldsymbol{g}^{(t)} \rVert_2}\}$，蓝线 $\eta = 10^{-10}$。蓝线在 (a) 中外层轮数最少，在 (b) 中总成本最高。

这组数据说明两点。第一，把内层解到接近精确，与 $\eta = 0.1$ 相比外层只少了三轮，乘积次数却是它的五倍。第二，表中自适应规则的乘积次数

7.1 Newton 法
7.2 阻尼 Newton 法
7.3 修正 Newton 法
7.4 非精确 Newton 法
7.5 收敛与计算成本
7.6 本章小结

并不最少，$\eta = 0.1$ 在这个例子上反而更好。自适应规则的好处是不需要调参并且保证局部快速收敛，而不是在每个问题上都最省。

还要注意目标 (7.38)的 Hessian 是三对角的，稀疏 Cholesky 分解每次只要 $O(n)$ 次运算，这种情况下精确 Newton 法也相当便宜。Newton-CG 的优势主要在 Hessian 稠密、结构不便分解、或者根本不想形成矩阵的时候。

三种手段的组合 阻尼、修正、非精确求解作用在迭代的不同环节，可以按需要组合。实际程序中常见的组合是：Hessian 可以分解时，用试探 δ 的修正 Cholesky 或对角平移加回溯；规模太大时，用 Newton-CG 加回溯，负曲率时截断。每一种组合的保证都要对应地核对：下降方向由哪一环保证，步长由哪一环保证，局部速度又由哪些量趋于零来保证。

7.6 本章小结

Newton 法把优化问题变成一串线性方程：在当前点用二次模型代替目标，解 $\boldsymbol{H}^{(t)}\boldsymbol{d}^{(t)} = -\boldsymbol{g}^{(t)}$，走到模型的极小点。Hessian 正定时这个方向下降；解处非退化、Hessian Lipschitz 且初始点足够近时，收敛是二次的。

完整的 Newton 步在其余情形下都可能出问题。本章把困难分成三类，每一类用一个独立的量来控制，如图 7.21所示。

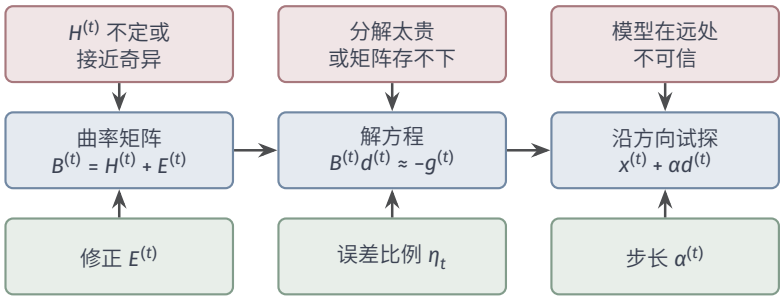


图 7.21 本章三种手段的分工。上行是遇到的困难，中行是迭代中受影响的环节，下行是对应的控制量。三个控制量互相独立，可以单独使用，也可以组合。

阻尼不改方向，只选步长 $\alpha^{(t)} \le 1$，靠原目标的下降检验保证进展。强凸时全局线性收敛，梯度足够小后完整步自动恢复，局部二次收敛得以保留。

修正改变曲率矩阵，用 $\boldsymbol{H}^{(t)} + \boldsymbol{E}^{(t)}$ 代替 Hessian。对角平移、谱修正和修正 Cholesky 分解在修正量和计算量之间取舍。修正量一致有界时梯度趋于零，极限点可能是鞍点；修正消失后恢复 Newton 的局部行为。

非精确求解放宽线性方程，用残差比例 η_t 规定内层精度。比例保持小于 1 得到线性收敛，趋于零得到超线性收敛，与梯度同阶得到二次收敛。Newton-CG 只用 Hessian 向量积，遇到非正曲率截断，方向总是下降的。

比较成本时要把外层轮数和内层工作一起计入，把远离解时的保障与解附近的速度分开看。局部收敛阶说明最后几步，总成本还取决于第一阶段的轮数和每轮的实际代价。

这些方法都要求能读取 Hessian 或它与向量的乘积。下一章研究不直接计算 Hessian 时，怎样从相邻两次梯度的变化中构造可用的曲率近似。

8.1 割线条件
8.2 DFP 与 BFGS
8.3 SR1
8.4 L-BFGS
8.5 收敛与计算成本
8.6 本章小结

第 8 章

拟牛顿法

假设目标有 $n = 10^4$ 个变量，算一次梯度只需几毫秒。第 7章的 Newton 法收敛很快，但它每一步都要形成 Hessian，保存约 5×10^7 个不同的元素，再做一次约 3×10^{11} 次运算的分解。第 6章的梯度下降每步只需要梯度，可是在狭长的山谷里它不断来回折返，因为它完全不知道地形朝哪个方向弯得厉害。

这两者之间有一个常被浪费的信息来源。迭代走了一步之后，我们手里有相邻两点的梯度，两个梯度的差反映了这一段路上地形的弯曲。这件事不需要额外的计算，只要把数字留下来。

本章研究怎样把这些“免费”的曲率测量攒成一个可用的矩阵。第 8.1节写出测量给出的条件，并说明为什么单靠它定不出矩阵。第 8.2节用两个秩一项做修正，得到 DFP 和 BFGS 两种更新，重点在怎样保持矩阵正定。

第 8.3节只用一个秩一项，它能记住负曲率，代价是失去正定性。第 8.4节处理连 $n \times n$ 矩阵都存不下的情形，只保留最近几次测量。第 8.5节在同一套条件下逐个核对这些方法能保证什么，并按相同精度比较计算成本。

全章用同一个二维目标做手算：

$$f(\boldsymbol{x}) = x_1^2 + 4x_2^2, \qquad \boldsymbol{x}^{(0)} = (4, 1)^{\top}. \tag{8.1}$$

它的 Hessian 是 $\boldsymbol{A} = \operatorname{diag}(2, 8)$，最优解是原点。算法并不知道 $\boldsymbol{A}$，它只能在迭代点上读取梯度 $\nabla f(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x}$。

8.1 割线条件

不计算 Hessian，单凭已经读到的梯度，能知道多少曲率？答案是一条线性方程组，它精确地说出了一次测量包含的信息，也说明了这些信息还远远不够。

用近似矩阵代替 Hessian　Newton 法在当前点 $\boldsymbol{x}^{(t)}$ 处用二次模型近似目标。把模型里的 Hessian 换成一个对称矩阵 $\boldsymbol{B}^{(t)}$，模型变成

$$m^{(t)}(\boldsymbol{p}) = f(\boldsymbol{x}^{(t)}) + \langle \boldsymbol{g}^{(t)}, \boldsymbol{p} \rangle + \frac{1}{2}\boldsymbol{p}^{\top}\boldsymbol{B}^{(t)}\boldsymbol{p}. \tag{8.2}$$

当 $\boldsymbol{B}^{(t)}$ 正定时，模型是严格凸的，令它的梯度 $\boldsymbol{g}^{(t)} + \boldsymbol{B}^{(t)}\boldsymbol{p}$ 为零，得到唯一极小点

$$\boldsymbol{d}^{(t)} = -\boldsymbol{W}^{(t)}\boldsymbol{g}^{(t)}, \qquad \boldsymbol{W}^{(t)} = \left(\boldsymbol{B}^{(t)}\right)^{-1}. \tag{8.3}$$

这里 $\boldsymbol{B}^{(t)}$ 叫曲率近似，$\boldsymbol{W}^{(t)}$ 叫逆曲率近似。全卷 $\boldsymbol{H}^{(t)}$ 专指真实 Hessian，所以逆近似用 $\boldsymbol{W}$ 表示。下面只需要回答一件事：这两个矩阵从哪里来。

一维情形：割线　先看只有一个变量的目标。设 $f(x) = \frac{1}{4}x^4 + \frac{1}{2}x^2$，梯度 $g(x) = x^3 + x$，已经走过 $x^{(0)} = 1$ 和 $x^{(1)} = 0.5$，读到

$$g(x^{(0)}) = 2, \qquad g(x^{(1)}) = 0.625.$$

过这两点作 g 的割线，斜率是

$$b = \frac{g(x^{(1)}) - g(x^{(0)})}{x^{(1)} - x^{(0)}} = \frac{0.625 - 2}{0.5 - 1} = 2.75.$$

这个斜率介于两端的真实二阶导数 $f''(0.5) = 1.75$ 与 $f''(1) = 4$ 之间。由微积分基本定理，它正好是 f'' 在这一段上的平均值。把 b 当作曲率，下一个点就是割线与横轴的交点：

$$x^{(2)} = x^{(1)} - \frac{g(x^{(1)})}{b} = 0.5 - \frac{0.625}{2.75} \approx 0.273.$$

图 8.1画出了这一步。割线不如切线精确，却不需要二阶导数，只用两次已经算过的梯度。

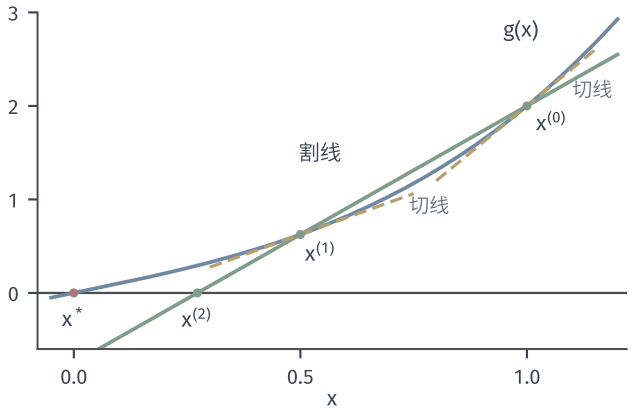


图 8.1　一维的割线步。蓝线是 $f(x)=\frac{1}{4}x^4+\frac{1}{2}x^2$ 的梯度 $g(x)=x^3+x$。绿线是过 $x^{(0)}=1$、$x^{(1)}=0.5$ 两点的割线，斜率 2.75 是 f'' 在这一段的平均值；两条黄色虚线是两端的切线，斜率分别为 4 和 1.75。割线与横轴的交点给出下一个迭代点 $x^{(2)}\approx 0.273$，红点是最优解。

高维情形：梯度差是平均曲率作用于位移　高维时除法做不了，但关系仍在。记位移与梯度差分别为

$$\boldsymbol{s}^{(t)}=\boldsymbol{x}^{(t+1)}-\boldsymbol{x}^{(t)},\qquad \boldsymbol{y}^{(t)}=\boldsymbol{g}^{(t+1)}-\boldsymbol{g}^{(t)}. \tag{8.4}$$

沿线段 $\boldsymbol{x}^{(t)}+\tau\boldsymbol{s}^{(t)}$（$\tau\in[0,1]$）对梯度用微积分基本定理，得到

$$\boldsymbol{y}^{(t)}=\bar{\boldsymbol{H}}^{(t)}\boldsymbol{s}^{(t)},\qquad \bar{\boldsymbol{H}}^{(t)}=\int_0^1 \nabla^2 f\big(\boldsymbol{x}^{(t)}+\tau\boldsymbol{s}^{(t)}\big)\,\mathrm{d}\tau. \tag{8.5}$$

所以 $\boldsymbol{y}^{(t)}$ 是这一段路上的平均 Hessian 作用在位移上的结果。对二次目标，Hessian 是常数 $\boldsymbol{A}$，等式成为精确的 $\boldsymbol{y}^{(t)}=\boldsymbol{A}\boldsymbol{s}^{(t)}$。

可以把每一步想成一次路试。车沿某条路开过去，记下坡度的变化，就知道这条路上地形弯得多厉害。对应关系是：路线对应 $\boldsymbol{s}^{(t)}$，坡度变化对应 $\boldsymbol{y}^{(t)}$，弯曲程度对应 $\bar{\boldsymbol{H}}^{(t)}$ 在这个方向上的作用。

这个类比有两处要小心。一次路试只告诉我们沿路线方向的信息，与路线垂直的方向几乎没有测量；地形不是二次的时候，旧路试测到的曲率会随着位置改变而过时。

既然模型要代表目标在下一个点的局部形状，自然要求新的矩阵重现最新的测量。

定义 8.1　割线条件　给定 $\boldsymbol{s}^{(t)}$ 与 $\boldsymbol{y}^{(t)}$，称对称矩阵 $\boldsymbol{B}^{(t+1)}$ 满足割线条件（secant condition），如果

$$\boldsymbol{B}^{(t+1)}\boldsymbol{s}^{(t)} = \boldsymbol{y}^{(t)}. \tag{8.6}$$

用逆曲率近似 $\boldsymbol{W}^{(t+1)}$ 表示时，条件写成

$$\boldsymbol{W}^{(t+1)}\boldsymbol{y}^{(t)} = \boldsymbol{s}^{(t)}. \tag{8.7}$$

割线条件有一个几何含义。以 $\boldsymbol{x}^{(t+1)}$ 为中心的模型在新点的梯度是 $\boldsymbol{g}^{(t+1)}$，在旧点（$\boldsymbol{p} = -\boldsymbol{s}^{(t)}$）的梯度是

$$\boldsymbol{g}^{(t+1)} - \boldsymbol{B}^{(t+1)}\boldsymbol{s}^{(t)} = \boldsymbol{g}^{(t+1)} - \boldsymbol{y}^{(t)} = \boldsymbol{g}^{(t)}.$$

也就是说，模型在新旧两点的梯度都与目标一致。使用满足割线条件的矩阵，并按这种方式选择方向的方法统称**拟牛顿法**（quasi-Newton method）。

下面用贯穿例算出第一组测量。取 $\boldsymbol{W}^{(0)} = \boldsymbol{I}$，第一步就是负梯度方向。在二次目标上，沿方向 $\boldsymbol{d}$ 的精确线搜索步长是

$$\alpha = \frac{-\langle \boldsymbol{g}, \boldsymbol{d} \rangle}{\boldsymbol{d}^{\top}\boldsymbol{A}\boldsymbol{d}}.$$

代入第一轮的数据，得到

$$\boldsymbol{g}^{(0)} = (8, 8)^{\top}, \qquad \boldsymbol{d}^{(0)} = (-8, -8)^{\top}, \qquad \alpha^{(0)} = \frac{128}{640} = \frac{1}{5}.$$

走完这一步，得到新的点和梯度：

$$\boldsymbol{x}^{(1)} = (2.4, -0.6)^{\top}, \qquad \boldsymbol{g}^{(1)} = (4.8, -4.8)^{\top}.$$

位移和梯度差是

$$\boldsymbol{s}^{(0)} = (-1.6, -1.6)^{\top}, \qquad \boldsymbol{y}^{(0)} = (-3.2, -12.8)^{\top}. \tag{8.8}$$

一条割线条件定不出矩阵　割线条件有 n 个方程，对称矩阵有 $n(n+1)/2$ 个自由元素，还差 $n(n-1)/2$ 个条件。$n = 1$ 时恰好相等，这正是一维割线法没有选择余地的原因。n 一大，缺口迅速变大。

图 8.2说明缺的是哪些信息。把 $\boldsymbol{s}$ 单位化后作为第一个基向量。$\boldsymbol{B}\boldsymbol{s} = \boldsymbol{y}$ 确定了矩阵的第一列，对称性再确定第一行，其余 $(n-1)\times(n-1)$ 的对称块完全自由。换句话说，矩阵在与 $\boldsymbol{s}$ 正交的子空间内怎样弯曲，这次路试没有提供任何信息。

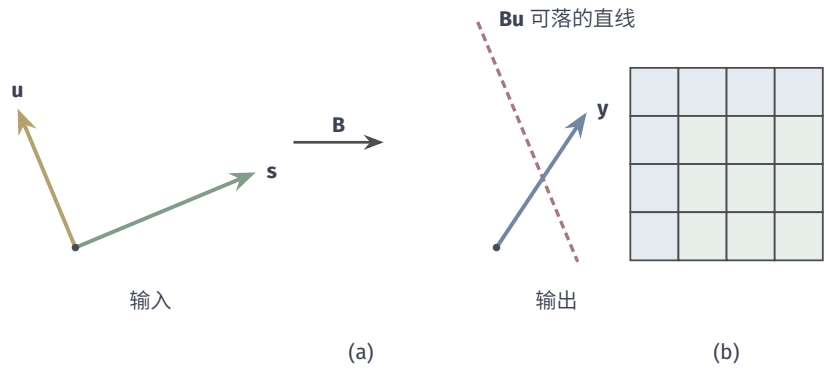


图 8.2 割线条件确定了矩阵的哪些部分。(a)$n=2$ 时，$\boldsymbol{B}$ 把 $\boldsymbol{s}$ 送到已知的 $\boldsymbol{y}$；对另一个方向 $\boldsymbol{u}$，对称性只给出 $\langle \boldsymbol{Bu}, \boldsymbol{s}\rangle = \langle \boldsymbol{u}, \boldsymbol{y}\rangle$，所以 $\boldsymbol{Bu}$ 只知道落在红色虚线上。(b)$n=4$ 时，在以 $\boldsymbol{s}$ 为第一个基向量的正交基下，蓝色的第一行第一列由割线条件和对称性确定，绿色的 3×3 对称块的 6 个元素仍然自由。

用贯穿例看得更具体。设 $\boldsymbol{B}=\begin{bmatrix} a & b \\ b & c \end{bmatrix}$，把式 (8.8)代入割线条件，两个方程约去公因子后是

$$a+b=2, \qquad b+c=8.$$

三个未知数、两个方程，还剩一个自由参数：

$$\boldsymbol{B}(a)=\begin{bmatrix} a & 2-a \\ 2-a & 6+a \end{bmatrix}, \qquad \det \boldsymbol{B}(a)=10a-4. \tag{8.9}$$

真实 Hessian 是其中 $a=2$ 的成员，但算法无从知道。

族中不同成员给出的方向也不同。若第一步取较短的步长 $\alpha^{(0)}=1/8$，位移与梯度差只差一个倍数，方程不变，于是仍是族 (8.9)。此时 $\boldsymbol{x}^{(1)}=(3,0)^{\mathsf{T}}$，$\boldsymbol{g}^{(1)}=(6,0)^{\mathsf{T}}$，方向 $-\boldsymbol{B}(a)^{-1}\boldsymbol{g}^{(1)}$ 的计算结果是

$$\begin{aligned} a=0.9:&\quad (-8.28,\ 1.32)^{\mathsf{T}},\\ a=2:&\quad (-3,\ 0)^{\mathsf{T}},\\ a=5:&\quad (-1.435,\ -0.391)^{\mathsf{T}}. \end{aligned}$$

只有 $a=2$ 的方向一步落到最优解。图 8.3(a) 把这些模型画在一起：它们在 $\boldsymbol{x}^{(0)}$ 处都与同一条红色切线相切，这是割线条件保证的，在别的地方却差别很大，极小点也各不相同。

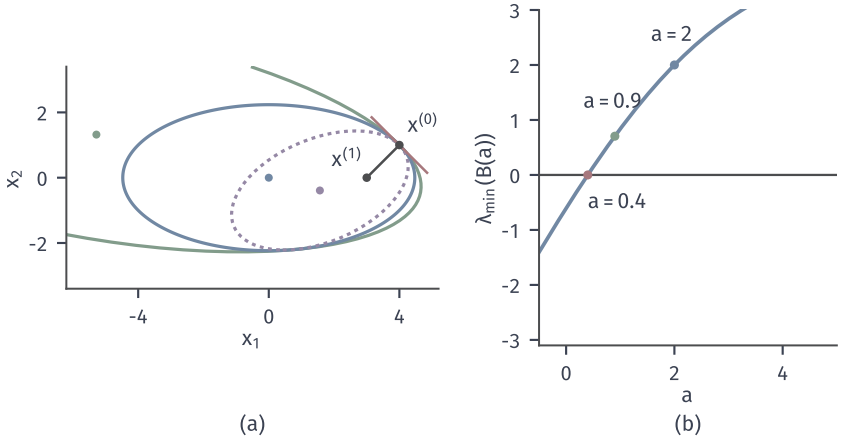


图 8.3 满足同一割线条件的矩阵族 (8.9)。(a) 从 $\boldsymbol{x}^{(0)}=(4,1)$ 走到 $\boldsymbol{x}^{(1)}=(3,0)$ 后，$a=0.9$（绿）、$a=2$（蓝）、$a=5$（紫，点线）三个模型过 $\boldsymbol{x}^{(0)}$ 的等值线，它们在 $\boldsymbol{x}^{(0)}$ 处有同一条切线（红），同色小点是各模型的极小点。(b)$\boldsymbol{B}(a)$ 的最小特征值，$a>0.4$ 时为正。

还要补充什么要求 既然割线条件不够，就要额外规定想要什么样的矩阵。后面各种方法的区别，就在这些补充要求上。

第一是**对称**。Hessian 对称，近似矩阵也应该对称，这已经写进了定义。

第二是**低秩修正**：$\boldsymbol{B}^{(t+1)}$ 与 $\boldsymbol{B}^{(t)}$ 只差一个秩很低的矩阵。这样做既保留了以前路试积累的信息，也使更新只花 $O(n^2)$ 次运算。它还能配合逆矩阵的公式，直接更新 $\boldsymbol{W}$，于是根本不用解线性方程。

第三是**曲率性质**。我们希望 $\boldsymbol{B}^{(t+1)}$ 正定，这样方向 (8.3)才是模型的极小点。但正定性对测量数据有要求。用 $\boldsymbol{s}^{(t)}$ 与割线条件 (8.6)作内积，得到

$$\left(\boldsymbol{s}^{(t)}\right)^{\top}\boldsymbol{B}^{(t+1)}\boldsymbol{s}^{(t)}=\langle \boldsymbol{s}^{(t)},\boldsymbol{y}^{(t)}\rangle. \tag{8.10}$$

左边在 $\boldsymbol{B}^{(t+1)}\succ\boldsymbol{0}$ 且 $\boldsymbol{s}^{(t)}\neq\boldsymbol{0}$ 时为正，所以必须有

$$\langle \boldsymbol{s}^{(t)},\boldsymbol{y}^{(t)}\rangle>0. \tag{8.11}$$

这个不等式称为**曲率条件**（curvature condition）。它的含义是：沿刚走过的路，平均来看地形向上弯。

曲率条件确实可能不成立。取不定的二次目标，其 Hessian 为 $\operatorname{diag}(2,-1)$，$\boldsymbol{s}=(1,2)^{\top}$，则

$$\boldsymbol{y}=(2,-2)^{\top},\qquad \langle \boldsymbol{s},\boldsymbol{y}\rangle=2-4=-2<0.$$

这时任何满足割线条件的矩阵都不可能正定。曲率条件是必要条件，第 8.2节将说明，配合恰当的更新，它也是充分的。

8.1 割线条件
8.2 DFP 与 BFGS
8.3 SR1
8.4 L-BFGS
8.5 收敛与计算成本
8.6 本章小结

接入线搜索 得到 $\boldsymbol{W}^{(t)}$ 后，拟牛顿法沿用第 5章的线搜索框架：

$$\boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} + \alpha^{(t)}\boldsymbol{d}^{(t)}, \qquad \boldsymbol{d}^{(t)} = -\boldsymbol{W}^{(t)}\boldsymbol{g}^{(t)}. \tag{8.12}$$

只要 $\boldsymbol{W}^{(t)}$ 正定且 $\boldsymbol{g}^{(t)} \neq \boldsymbol{0}$，就有

$$\langle \boldsymbol{g}^{(t)}, \boldsymbol{d}^{(t)} \rangle = -\left(\boldsymbol{g}^{(t)}\right)^{\top} \boldsymbol{W}^{(t)} \boldsymbol{g}^{(t)} < 0,$$

方向是下降方向，线搜索一定能找到使目标下降的步长。

步长的试探从 $\alpha = 1$ 开始，因为 $\boldsymbol{d}^{(t)}$ 本身是模型的极小点，近似矩阵好的时候它就是合适的长度。常用的接受标准是 Wolfe 条件：取 $0 < c_1 < c_2 < 1$，要求 α 同时满足充分下降和曲率两条不等式，

$$\begin{aligned} f(\boldsymbol{x}^{(t)} + \alpha\boldsymbol{d}^{(t)}) &\le f(\boldsymbol{x}^{(t)}) + c_1\alpha\langle \boldsymbol{g}^{(t)}, \boldsymbol{d}^{(t)} \rangle, \\ \langle \nabla f(\boldsymbol{x}^{(t)} + \alpha\boldsymbol{d}^{(t)}), \boldsymbol{d}^{(t)} \rangle &\ge c_2\langle \boldsymbol{g}^{(t)}, \boldsymbol{d}^{(t)} \rangle. \end{aligned} \tag{8.13}$$

第一条不让步长过长，第二条不让步长过短。第 5章已经说明，下降方向上目标有下界时，这样的步长总是存在。第二条在这里还有一个专门的用途，下一节会看到。

把三类方向放在一起，能看清拟牛顿法的位置。它们的区别不在迭代的形式，而在第一项的矩阵由什么信息构成。

方法	方向	用到的信息	每步新增的曲率信息
梯度下降	$-\boldsymbol{g}^{(t)}$	梯度	无
拟牛顿法	$-\boldsymbol{W}^{(t)}\boldsymbol{g}^{(t)}$	梯度与历史	一次沿位移的测量
Newton 法	$-(\boldsymbol{H}^{(t)})^{-1}\boldsymbol{g}^{(t)}$	梯度与 Hessian	完整的曲率

表 8.1 三类方向的对比。

8.2 DFP 与 BFGS

割线条件留下了很大的自由度。接下来要弄清：怎样用尽量小的对称修正满足它，同时让矩阵保持正定？答案是两个秩一项之和，改动的对象不同，就得到 DFP 和 BFGS 两种更新。

讨论一次更新时省略迭代上标：当前矩阵写作 $\boldsymbol{B}$、$\boldsymbol{W}$，新矩阵写作 $\boldsymbol{B}^{+}$、$\boldsymbol{W}^{+}$，位移和梯度差写作 $\boldsymbol{s}$、$\boldsymbol{y}$，并记

$$\rho = \frac{1}{\langle \boldsymbol{s}, \boldsymbol{y} \rangle}. \tag{8.14}$$

主要思想：秩二修正 设新矩阵是旧矩阵加上两个对称秩一项：

$$\boldsymbol{B}^{+} = \boldsymbol{B} + a\boldsymbol{u}\boldsymbol{u}^{\top} + b\boldsymbol{v}\boldsymbol{v}^{\top}.$$

代入割线条件 $\boldsymbol{B}^{+}\boldsymbol{s} = \boldsymbol{y}$，得到

$$\boldsymbol{B}\boldsymbol{s} + a\langle \boldsymbol{u}, \boldsymbol{s}\rangle \boldsymbol{u} + b\langle \boldsymbol{v}, \boldsymbol{s}\rangle \boldsymbol{v} = \boldsymbol{y}.$$

这个等式左边有三个向量，右边是 $\boldsymbol{y}$。最直接的配法是让新增的一项产生 $\boldsymbol{y}$，另一项抵消 $\boldsymbol{B}\boldsymbol{s}$，也就是取 $\boldsymbol{u} = \boldsymbol{y}$，$\boldsymbol{v} = \boldsymbol{B}\boldsymbol{s}$，并令

$$a\langle \boldsymbol{y}, \boldsymbol{s}\rangle = 1, \qquad b\,\boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s} = -1.$$

由此得到BFGS 更新（BFGS update）：

$$\boldsymbol{B}^{+} = \boldsymbol{B} - \frac{\boldsymbol{B}\boldsymbol{s}\boldsymbol{s}^{\top}\boldsymbol{B}}{\boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s}} + \rho\, \boldsymbol{y}\boldsymbol{y}^{\top}. \tag{8.15}$$

名称取自 Broyden、Fletcher、Goldfarb 和 Shanno 四人。

更新的两项各做一件事。把旧矩阵减去第一项后的结果记为

$$\boldsymbol{P} = \boldsymbol{B} - \frac{\boldsymbol{B}\boldsymbol{s}\boldsymbol{s}^{\top}\boldsymbol{B}}{\boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s}}.$$

它满足 $\boldsymbol{P}\boldsymbol{s} = \boldsymbol{0}$，也就是把旧矩阵沿 $\boldsymbol{s}$ 的曲率清空了。第二项把新测到的曲率填回去，因为 $\rho\, \boldsymbol{y}\boldsymbol{y}^{\top}\boldsymbol{s} = \boldsymbol{y}$。

图 8.4按贯穿例的第一次更新画出这个过程。旧矩阵的单位等值线是圆；清空沿 $\boldsymbol{s}$ 的曲率之后，它变成沿 $\boldsymbol{s}$ 无限延伸的带；加上测量项后，带又合拢成椭圆，形状已经向真实 Hessian 靠拢。

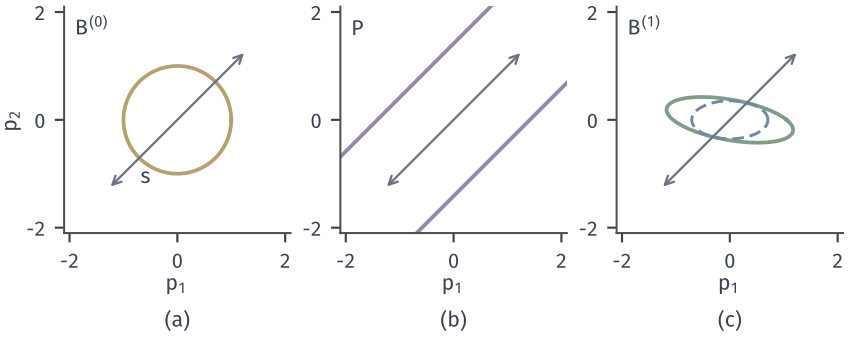


图 8.4 贯穿例第一次 BFGS 更新的两步，曲线都是集合 $\{\boldsymbol{p} : \boldsymbol{p}^{\top}\boldsymbol{M}\boldsymbol{p} = 1\}$，箭头是 $\boldsymbol{s}^{(0)}$ 所在的直线。(a)$\boldsymbol{M} = \boldsymbol{B}^{(0)} = \boldsymbol{I}$。(b)$\boldsymbol{M} = \boldsymbol{P}$，沿 $\boldsymbol{s}$ 的曲率被清空，等值线变成平行的两条直线（紫）。(c)$\boldsymbol{M} = \boldsymbol{B}^{(1)}$（绿），加上测量项后重新合拢；蓝色虚线是真实 Hessian 的等值线。

主要思想：对偶的 DFP 把同样的推导用在逆矩阵上。设 $\boldsymbol{W}^+$ 是 $\boldsymbol{W}$ 加上两个对称秩一项，代入割线条件 (8.7)，取一项产生 $\boldsymbol{s}$，另一项抵消 $\boldsymbol{W}\boldsymbol{y}$，得到DFP 更新（DFP update）：

$$\boldsymbol{W}^+ = \boldsymbol{W} - \frac{\boldsymbol{W}\boldsymbol{y}\boldsymbol{y}^\top \boldsymbol{W}}{\boldsymbol{y}^\top \boldsymbol{W}\boldsymbol{y}} + \rho\, \boldsymbol{s}\boldsymbol{s}^\top. \tag{8.16}$$

名称取自 Davidon、Fletcher 和 Powell 三人。对比式 (8.15)，两者互为对偶：在一个公式里交换 $\boldsymbol{B} \leftrightarrow \boldsymbol{W}$、$\boldsymbol{s} \leftrightarrow \boldsymbol{y}$，就得到另一个。

实际计算只需要 $\boldsymbol{W}$，方向 (8.3)才不用解方程。DFP 本来就是 $\boldsymbol{W}$ 的公式，BFGS 却要从 $\boldsymbol{B}$ 翻译过来。下面的定理给出翻译的结果。

定理 8.2 BFGS 的逆形式 设 $\boldsymbol{B} \succ \boldsymbol{0}$，$\boldsymbol{W} = \boldsymbol{B}^{-1}$，$\boldsymbol{s} \neq \boldsymbol{0}$，$\langle \boldsymbol{s}, \boldsymbol{y} \rangle > 0$，并记 $\boldsymbol{V} = \boldsymbol{I} - \rho\, \boldsymbol{y}\boldsymbol{s}^\top$。则式 (8.15)的 $\boldsymbol{B}^+$ 可逆，其逆是

$$\boldsymbol{W}^+ = \boldsymbol{V}^\top \boldsymbol{W}\boldsymbol{V} + \rho\, \boldsymbol{s}\boldsymbol{s}^\top. \tag{8.17}$$

证明 只需验证 $\boldsymbol{B}^+\boldsymbol{W}^+ = \boldsymbol{I}$。先处理 $\boldsymbol{B}^+\boldsymbol{V}^\top$。因为 $\boldsymbol{V}^\top = \boldsymbol{I} - \rho\, \boldsymbol{s}\boldsymbol{y}^\top$，且 $\boldsymbol{B}^+\boldsymbol{s} = \boldsymbol{y}$，所以

$$\boldsymbol{B}^+\boldsymbol{V}^\top = \boldsymbol{B}^+ - \rho\, \boldsymbol{y}\boldsymbol{y}^\top = \boldsymbol{P}.$$

再乘 $\boldsymbol{W}$，由 $\boldsymbol{B}\boldsymbol{W} = \boldsymbol{I}$，得到

$$\boldsymbol{P}\boldsymbol{W} = \boldsymbol{I} - \frac{\boldsymbol{B}\boldsymbol{s}\boldsymbol{s}^\top}{\boldsymbol{s}^\top \boldsymbol{B}\boldsymbol{s}}.$$

接着由 ρ 的定义计算 $\boldsymbol{s}^\top \boldsymbol{V}$：

$$\boldsymbol{s}^\top \boldsymbol{V} = \boldsymbol{s}^\top - \rho \langle \boldsymbol{s}, \boldsymbol{y} \rangle \boldsymbol{s}^\top = \boldsymbol{0}^\top.$$

所以右乘 $\boldsymbol{V}$ 时第二项消失：

$$\boldsymbol{P}\boldsymbol{W}\boldsymbol{V} = \boldsymbol{V}.$$

最后合并 $\boldsymbol{W}^+$ 的两部分，并再用一次 $\boldsymbol{B}^+\boldsymbol{s} = \boldsymbol{y}$：

$$\boldsymbol{B}^+\boldsymbol{W}^+ = \boldsymbol{P}\boldsymbol{W}\boldsymbol{V} + \rho\, \boldsymbol{B}^+\boldsymbol{s}\boldsymbol{s}^\top = \boldsymbol{V} + \rho\, \boldsymbol{y}\boldsymbol{s}^\top = \boldsymbol{I}.$$

方阵有右逆即可逆，定理得证。 ∎

同样的公式也可以两次使用 Sherman–Morrison 公式得到，秩一修正求逆的公式可参考卷二第 12 章“线性方程的直接求解”。对偶地，DFP 的直接形式是

$$\boldsymbol{B}^{+} = \boldsymbol{V}\boldsymbol{B}\boldsymbol{V}^{\top} + \rho\, \boldsymbol{y}\boldsymbol{y}^{\top}. \tag{8.18}$$

主要思想：新测量取代旧记忆 逆形式 (8.17)有一个清楚的解释。任取向量 $\boldsymbol{z}$，令 $a = \rho\langle \boldsymbol{s}, \boldsymbol{z}\rangle$，由 $\boldsymbol{V}$ 的定义，

$$\boldsymbol{z} = a\,\boldsymbol{y} + \boldsymbol{V}\boldsymbol{z}, \qquad \langle \boldsymbol{s}, \boldsymbol{V}\boldsymbol{z}\rangle = 0. \tag{8.19}$$

也就是说，$\boldsymbol{z}$ 被拆成沿 $\boldsymbol{y}$ 的部分和与 $\boldsymbol{s}$ 正交的部分（这个拆分不是正交分解）。

把 $\boldsymbol{W}^{+}$ 作用到 $\boldsymbol{z}$ 上，得到

$$\boldsymbol{W}^{+}\boldsymbol{z} = a\,\boldsymbol{s} + \boldsymbol{V}^{\top}\boldsymbol{W}\boldsymbol{V}\boldsymbol{z}.$$

沿 $\boldsymbol{y}$ 的部分直接按测量结果换成 $\boldsymbol{s}$，这正是割线条件；其余部分仍用旧矩阵 $\boldsymbol{W}$ 处理，只是最后用 $\boldsymbol{V}^{\top}$ 投影到 $\boldsymbol{y}$ 的正交补上。图 8.5画出了这个分解。

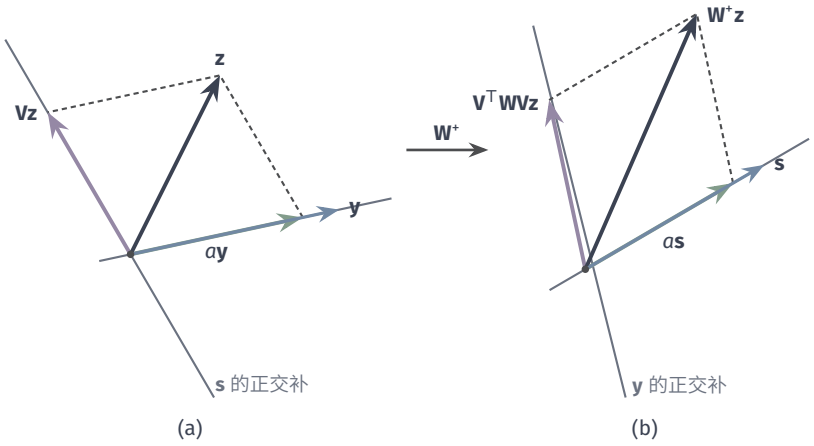


图 8.5 BFGS 逆更新对向量 $\boldsymbol{z}$ 的作用，示意中旧矩阵取 $\boldsymbol{W} = \boldsymbol{I}$。(a)$\boldsymbol{z}$ 沿 $\boldsymbol{y}$ 与 $\boldsymbol{s}$ 的正交补拆成两部分。(b) 沿 $\boldsymbol{y}$ 的部分 $a\boldsymbol{y}$ 被换成 $a\boldsymbol{s}$（绿），其余部分经旧矩阵后落在 $\boldsymbol{y}$ 的正交补上（紫），两者相加得到 $\boldsymbol{W}^{+}\boldsymbol{z}$。

BFGS 还有一个“改动最小”的刻画，它说明了在割线条件的整个解族中为什么选这一个。设 $\boldsymbol{G}$ 是任意满足 $\boldsymbol{G}\boldsymbol{s} = \boldsymbol{y}$ 的对称正定矩阵，例如 $\bar{\boldsymbol{H}}$ 正定时的平均 Hessian。在所有满足 $\boldsymbol{W} = \boldsymbol{W}^{\top}$、$\boldsymbol{W}\boldsymbol{y} = \boldsymbol{s}$ 的矩阵中，BFGS 的 $\boldsymbol{W}^{+}$ 使加权距离 $\|\boldsymbol{G}^{1/2}(\boldsymbol{W} - \boldsymbol{W}_{\text{old}})\boldsymbol{G}^{1/2}\|_F$ 最小。

对偶地，DFP 的 $\boldsymbol{B}^{+}$ 在类似的约束下使 $\|\boldsymbol{G}^{-1/2}(\boldsymbol{B} - \boldsymbol{B}_{\text{old}})\boldsymbol{G}^{-1/2}\|_F$ 最小。证明需要把加权范数下的投影算出来，篇幅较长，读者可查阅[1]。它的含

[1] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

义是：两种更新都尽量保留旧矩阵，只是一个在逆矩阵上度量改动，另一个在矩阵本身上度量改动。

曲率条件保证正定 上一节说明曲率条件 (8.11)是正定性的必要条件。现在证明，对 BFGS 和 DFP 它也是充分的。

定理 8.3 正定性的保持 设 $\boldsymbol{W} \succ \mathbf{0}$，$\boldsymbol{s} \neq \mathbf{0}$，$\boldsymbol{y} \neq \mathbf{0}$。则 BFGS 的 $\boldsymbol{W}^+$ 与 DFP 的 $\boldsymbol{W}^+$ 都正定，当且仅当 $\langle \boldsymbol{s}, \boldsymbol{y} \rangle > 0$。

证明 必要性：割线条件 $\boldsymbol{W}^+ \boldsymbol{y} = \boldsymbol{s}$ 与 $\boldsymbol{y}$ 作内积，得到

$$\boldsymbol{y}^\top \boldsymbol{W}^+ \boldsymbol{y} = \langle \boldsymbol{s}, \boldsymbol{y} \rangle.$$

若 $\boldsymbol{W}^+ \succ \mathbf{0}$，左边为正。

BFGS 的充分性：对任意 $\boldsymbol{z} \neq \mathbf{0}$，由式 (8.17)，

$$\boldsymbol{z}^\top \boldsymbol{W}^+ \boldsymbol{z} = (\boldsymbol{V}\boldsymbol{z})^\top \boldsymbol{W} (\boldsymbol{V}\boldsymbol{z}) + \rho \langle \boldsymbol{s}, \boldsymbol{z} \rangle^2.$$

两项都非负。若第二项为零，则 $\langle \boldsymbol{s}, \boldsymbol{z} \rangle = 0$，此时 $\boldsymbol{V}\boldsymbol{z} = \boldsymbol{z} \neq \mathbf{0}$，第一项严格为正；所以和严格为正。

DFP 的充分性：式 (8.18)在结构上就是把式 (8.17)中的 $(\boldsymbol{W}, \boldsymbol{s}, \boldsymbol{y})$ 换成 $(\boldsymbol{B}, \boldsymbol{y}, \boldsymbol{s})$，同样的论证给出 $\boldsymbol{B}^+ \succ \mathbf{0}$，因而 $\boldsymbol{W}^+ \succ \mathbf{0}$。 ■

Wolfe 线搜索的作用 剩下的问题是让曲率条件真的成立。第 8.1节留下的第二条 Wolfe 不等式正是为此准备的。记 $\boldsymbol{s} = \alpha \boldsymbol{d}$，用第二条不等式，得到

$$\langle \boldsymbol{y}, \boldsymbol{d} \rangle = \langle \boldsymbol{g}^+, \boldsymbol{d} \rangle - \langle \boldsymbol{g}, \boldsymbol{d} \rangle \geq (c_2 - 1) \langle \boldsymbol{g}, \boldsymbol{d} \rangle.$$

再乘以 $\alpha > 0$，由 $c_2 < 1$ 和 $\langle \boldsymbol{g}, \boldsymbol{d} \rangle < 0$，右端为正，于是

$$\langle \boldsymbol{s}, \boldsymbol{y} \rangle \geq \alpha (c_2 - 1) \langle \boldsymbol{g}, \boldsymbol{d} \rangle > 0. \tag{8.20}$$

所以 Wolfe 线搜索对任意光滑目标都保证曲率条件，不需要目标是凸的。

只有充分下降条件是不够的。图 8.6取一维函数 $\phi(\alpha) = f(\boldsymbol{x} + \alpha \boldsymbol{d})$，其导数为 $\phi'(\alpha) = -1 - 1.5\alpha + \alpha^3$，它在起点附近向下弯。由 $\boldsymbol{s} = \alpha \boldsymbol{d}$，曲率条件等价于 $\phi'(\alpha) > \phi'(0)$。取 $\alpha = 0.5$，充分下降条件（$c_1 = 0.1$）成立，但

$$\phi'(0.5) = -1.625 < -1 = \phi'(0),$$

曲率条件失败。取 $c_2 = 0.5$ 时，第二条 Wolfe 不等式要求 $\phi'(\alpha) \geq -0.5$，这把步长推到了 $\alpha \geq 1.37$，那里曲率的平均值已经为正。

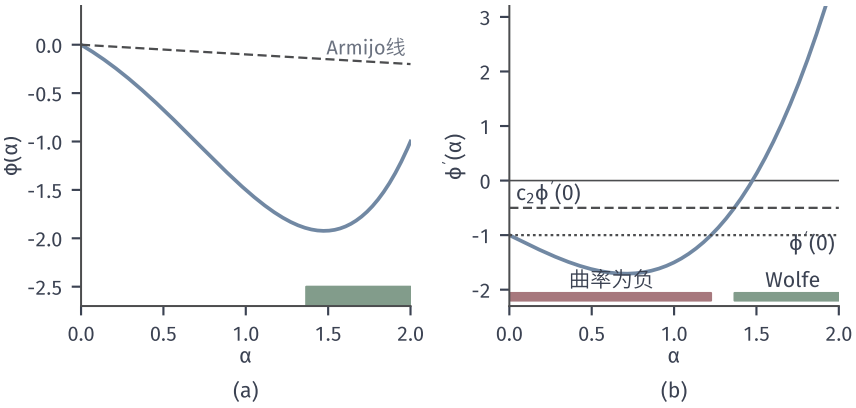


图 8.6 Wolfe 条件怎样保证曲率条件，$\phi'(\alpha) = -1 - 1.5\alpha + \alpha^3$，$c_1 = 0.1$，$c_2 = 0.5$。(a)$\phi$（蓝）和充分下降的边界线（虚线），底部绿条是 Wolfe 条件的可接受步长。(b)ϕ'（蓝）。红条上的步长满足 $\phi'(\alpha) < \phi'(0)$，曲率条件失败；绿条上的步长满足 $\phi'(\alpha) \geq c_2\phi'(0)$。

不用 Wolfe 时：跳过与阻尼 有时线搜索只做回溯，或者步长由别的机制决定，曲率条件就可能不成立。这时有两种处理。

跳过更新：取小的正数 ε_c（如 10^{-8}），当

$$\langle \boldsymbol{s}, \boldsymbol{y} \rangle \leq \varepsilon_c \|\boldsymbol{s}\|_2 \|\boldsymbol{y}\|_2 \tag{8.21}$$

时令 $\boldsymbol{W}^+ = \boldsymbol{W}$。它保持正定，代价是这一次测量被扔掉。

阻尼更新：不扔掉测量，而是把 $\boldsymbol{y}$ 与 $\boldsymbol{Bs}$ 混合，使混合后的向量满足曲率要求。记曲率比

$$\tau = \frac{\langle \boldsymbol{s}, \boldsymbol{y} \rangle}{\boldsymbol{s}^\top \boldsymbol{B}\boldsymbol{s}},$$

再取

$$\theta = \begin{cases} 1, & \tau \geq 0.2, \\ \dfrac{0.8}{1-\tau}, & \tau < 0.2, \end{cases} \qquad \boldsymbol{r} = \theta \boldsymbol{y} + (1-\theta)\boldsymbol{B}\boldsymbol{s}, \tag{8.22}$$

再用 $\boldsymbol{r}$ 代替 $\boldsymbol{y}$ 代入式 (8.15)。

这样处理后 $\tau < 0.2$ 时的曲率比正好是 0.2，因为

$$\frac{\langle \boldsymbol{s}, \boldsymbol{r} \rangle}{\boldsymbol{s}^\top \boldsymbol{B}\boldsymbol{s}} = \theta\tau + 1 - \theta = 1 - \theta(1-\tau) = 0.2.$$

曲率比大于零，由定理 8.3，$\boldsymbol{B}^+$ 正定。

用第 8.1节的不定例子算一次。取 $\boldsymbol{B}=\boldsymbol{I}$，$\boldsymbol{s}=(1,2)^{\top}$，$\boldsymbol{y}=(2,-2)^{\top}$，则 $\boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s}=5$，$\tau=-0.4$，于是

$$\theta=\frac{0.8}{1.4}=\frac{4}{7},\qquad \boldsymbol{r}=\frac{4}{7}(2,-2)^{\top}+\frac{3}{7}(1,2)^{\top}=\Big(\frac{11}{7},-\frac{2}{7}\Big)^{\top}.$$

验算：$\langle \boldsymbol{s},\boldsymbol{r}\rangle = 11/7-4/7=1=0.2\times 5$。图 8.7是 θ 和修正前后曲率比的变化。

要注意阻尼放弃了什么：新矩阵满足 $\boldsymbol{B}^{+}\boldsymbol{s}=\boldsymbol{r}$，而不再满足原来的割线条件。下表比较这三种机制。

机制	曲率条件	代价
Wolfe 线搜索	由线搜索保证	可能多几次函数和梯度计算
跳过更新	不成立时不更新	丢掉这次测量
阻尼更新	由混合后的 $\boldsymbol{r}$ 保证	放弃原来的割线条件

表 8.2　保持正定性的三种机制。

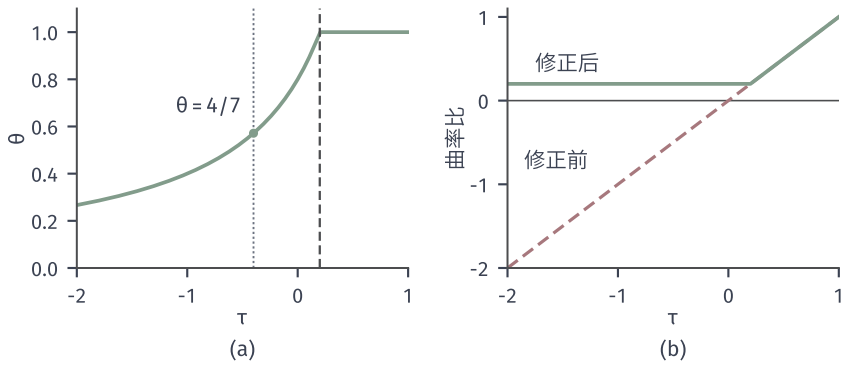


图 8.7　阻尼更新。(a) 式 (8.22)中的混合系数 θ 随曲率比 τ 的变化，虚线是阈值 $\tau=0.2$，绿点是例中的 $\tau=-0.4$，$\theta=4/7$。(b) 修正前（红虚线）与修正后（绿）的曲率比，修正后不低于 0.2。

计算过程　下面用贯穿例 (8.1)完整走一遍 BFGS，步长取精确线搜索，它在二次目标上满足 Wolfe 条件。

变量

- $\boldsymbol{x}^{(t)}\in\mathbb{R}^{n}$：当前迭代点；$\boldsymbol{g}^{(t)}\in\mathbb{R}^{n}$：当前梯度。
- $\boldsymbol{W}^{(t)}\in\mathbb{R}^{n\times n}$：对称正定的逆曲率近似。
- $\boldsymbol{d}^{(t)}$、$\alpha^{(t)}$：方向与步长。
- $\boldsymbol{s}^{(t)}$、$\boldsymbol{y}^{(t)}\in\mathbb{R}^{n}$、$\rho^{(t)}$：位移、梯度差与 $1/\langle \boldsymbol{s}^{(t)},\boldsymbol{y}^{(t)}\rangle$。

初始化　选起点 $\boldsymbol{x}^{(0)}$ 和对称正定的 $\boldsymbol{W}^{(0)}$，通常取单位矩阵的倍数，并计算 $\boldsymbol{g}^{(0)}$。例中初始数据是

$$\boldsymbol{x}^{(0)} = (4, 1)^{\top}, \qquad \boldsymbol{W}^{(0)} = \boldsymbol{I}, \qquad \boldsymbol{g}^{(0)} = (8, 8)^{\top}.$$

每轮更新　对 $t = 0, 1, \ldots$ 依次执行下面的步骤，当 $\|\boldsymbol{g}^{(t)}\|_2 \le \varepsilon$ 时停止。

1. 由式 (8.3)计算方向 $\boldsymbol{d}^{(t)} = -\boldsymbol{W}^{(t)}\boldsymbol{g}^{(t)}$。例中第一轮 $\boldsymbol{d}^{(0)} = (-8, -8)^{\top}$。
2. 沿 $\boldsymbol{d}^{(t)}$ 做满足式 (8.13)的线搜索，优先试 $\alpha = 1$。例中用精确线搜索，第一轮的步长是
$$\alpha^{(0)} = \frac{1}{5}.$$
3. 更新迭代点并计算新梯度。例中第一轮得到
$$\boldsymbol{x}^{(1)} = (2.4, -0.6)^{\top}, \qquad \boldsymbol{g}^{(1)} = (4.8, -4.8)^{\top}.$$
4. 由式 (8.4)计算 $\boldsymbol{s}^{(t)}$、$\boldsymbol{y}^{(t)}$ 和 $\rho^{(t)}$，并检查曲率条件。例中第一轮的 $\boldsymbol{s}^{(0)}$、$\boldsymbol{y}^{(0)}$ 由式 (8.8)给出，且
$$\langle \boldsymbol{s}^{(0)}, \boldsymbol{y}^{(0)} \rangle = 25.6, \qquad \rho^{(0)} = \frac{1}{25.6}.$$
5. 用 $\boldsymbol{s}^{(t)}$、$\boldsymbol{y}^{(t)}$、$\rho^{(t)}$ 构成定理 8.2中的 $\boldsymbol{V}$，由式 (8.17)更新 $\boldsymbol{W}^{(t+1)}$。例中第一轮的两个中间量是
$$\boldsymbol{V} = \begin{bmatrix} 0.8 & -0.2 \\ -0.8 & 0.2 \end{bmatrix}, \qquad \rho^{(0)}\boldsymbol{s}^{(0)}\big(\boldsymbol{s}^{(0)}\big)^{\top} = \begin{bmatrix} 0.1 & 0.1 \\ 0.1 & 0.1 \end{bmatrix}.$$
由此得到
$$\boldsymbol{W}^{(1)} = \boldsymbol{V}^{\top}\boldsymbol{V} + \rho^{(0)}\boldsymbol{s}^{(0)}\big(\boldsymbol{s}^{(0)}\big)^{\top} = \begin{bmatrix} 1.38 & -0.22 \\ -0.22 & 0.18 \end{bmatrix}.$$
$\boldsymbol{W}^{(1)}$ 的逆是
$$\boldsymbol{B}^{(1)} = \begin{bmatrix} 0.9 & 1.1 \\ 1.1 & 6.9 \end{bmatrix},$$
即族 (8.9)中 $a = 0.9$ 的成员。验算割线条件，$\boldsymbol{W}^{(1)}\boldsymbol{y}^{(0)}$ 算出来确实是 $(-1.6, -1.6)^{\top}$，也就是 $\boldsymbol{s}^{(0)}$。

第二轮按同样的步骤进行。方向和精确步长是

$$\boldsymbol{d}^{(1)} = -\boldsymbol{W}^{(1)}\boldsymbol{g}^{(1)} = (-7.68, 1.92)^{\top}, \qquad \alpha^{(1)} = \frac{46.08}{147.456} = \frac{5}{16}.$$

于是迭代点到达

$$\boldsymbol{x}^{(2)} = \boldsymbol{x}^{(1)} + \alpha^{(1)}\boldsymbol{d}^{(1)} = (0,0)^{\top}, \qquad \boldsymbol{g}^{(2)} = \boldsymbol{0}.$$

梯度为零，迭代结束。

为了看矩阵学到了什么，再做一次更新。这时有

$$\boldsymbol{s}^{(1)} = (-2.4, 0.6)^{\top}, \qquad \boldsymbol{y}^{(1)} = (-4.8, 4.8)^{\top}, \qquad \rho^{(1)} = \frac{1}{14.4}.$$

由式 (8.17)得到

$$\boldsymbol{W}^{(2)} = \begin{bmatrix} 0.5 & 0 \\ 0 & 0.125 \end{bmatrix} = \boldsymbol{A}^{-1}.$$

最终得到解 $\boldsymbol{x}^{(2)} = \boldsymbol{0}$，而且两次测量之后逆曲率近似恰好等于真实 Hessian 的逆。图 8.8展示了路径和矩阵的变化。

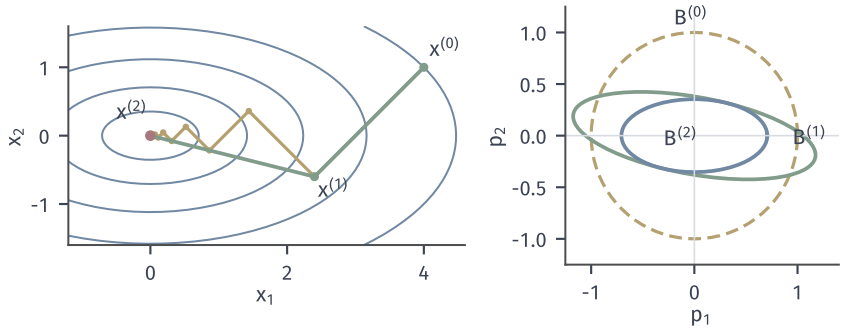


图 8.8　贯穿例上的 BFGS。(a) 蓝线是 $f(\boldsymbol{x}) = x_1^2 + 4x_2^2$ 的等高线，绿线是 BFGS（$\boldsymbol{W}^{(0)} = \boldsymbol{I}$，精确线搜索）的两步，黄线是相同起点的最速下降。(b) 集合 $\{\boldsymbol{p} : \boldsymbol{p}^{\top}\boldsymbol{B}^{(t)}\boldsymbol{p} = 1\}$，从圆（黄虚线）经过倾斜的椭圆（绿）变成真实 Hessian 的等值线（蓝）。

这不是巧合。在正定二次目标上使用精确线搜索时，BFGS 产生的方向两两关于 Hessian 共轭，至多 n 步到达最优解，并且 $\boldsymbol{W}^{(n)} = \boldsymbol{A}^{-1}$；第二次更新也没有破坏第一次的测量，例中可以验算 $\boldsymbol{W}^{(2)}\boldsymbol{y}^{(0)} = \boldsymbol{s}^{(0)}$。证明用对步数的归纳法，篇幅较长，读者可查阅[2]。这个结论依赖精确线搜索和二次目标，一般目标上不成立。

[2] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

DFP 与 BFGS 的对比　用同一个例子算 DFP。第一轮的 $\boldsymbol{s}^{(0)}$、$\boldsymbol{y}^{(0)}$ 相同，由式 (8.16)得到

$$\boldsymbol{W}^{(1)}_{\mathrm{DFP}} = \frac{1}{170}\begin{bmatrix} 177 & -23 \\ -23 & 27 \end{bmatrix}.$$

8.1 割线条件
8.2 DFP 与 BFGS
8.3 SR1
8.4 L-BFGS
8.5 收敛与计算成本
8.6 本章小结

它的逆是族 (8.9)中 $a = 1.08$ 的成员。

矩阵不同，第二轮的方向却平行，$\boldsymbol{d}_{\mathrm{DFP}}^{(1)}$ 约为 $(-5.647, 1.412)^{\mathsf{T}}$，正好是 BFGS 方向的 0.735 倍。原因在于精确线搜索使 $\langle \boldsymbol{g}^{(1)}, \boldsymbol{s}^{(0)} \rangle = 0$，再由割线条件和 $\boldsymbol{d}^{(1)} = -\boldsymbol{W}^{(1)}\boldsymbol{g}^{(1)}$，得到

$$\langle \boldsymbol{y}^{(0)}, \boldsymbol{d}^{(1)} \rangle = -\langle \boldsymbol{W}^{(1)}\boldsymbol{y}^{(0)}, \boldsymbol{g}^{(1)} \rangle = -\langle \boldsymbol{s}^{(0)}, \boldsymbol{g}^{(1)} \rangle = 0.$$

二维时这确定了方向。两种方法在这个例子上走过完全相同的点。

一旦线搜索不精确，差别就显现出来。图 8.9在一个 10 维强凸目标上比较两者，线搜索都满足强 Wolfe 条件。初始矩阵取 $\boldsymbol{I}$ 时，两者都在约 20 步内收敛。

把初始矩阵缩小为 $10^{-3}\boldsymbol{I}$，相当于矩阵 $\boldsymbol{B}^{(0)}$ 的曲率估计过大，BFGS 用 74 步恢复，DFP 在 300 步后梯度大小仍约为 3.9。这种从错误的曲率估计中恢复的能力称为自校正。第 8.5节会用一个势函数解释 BFGS 的自校正，那个论证对 DFP 不适用。这就是实践中通常用 BFGS 而不用 DFP 的原因。

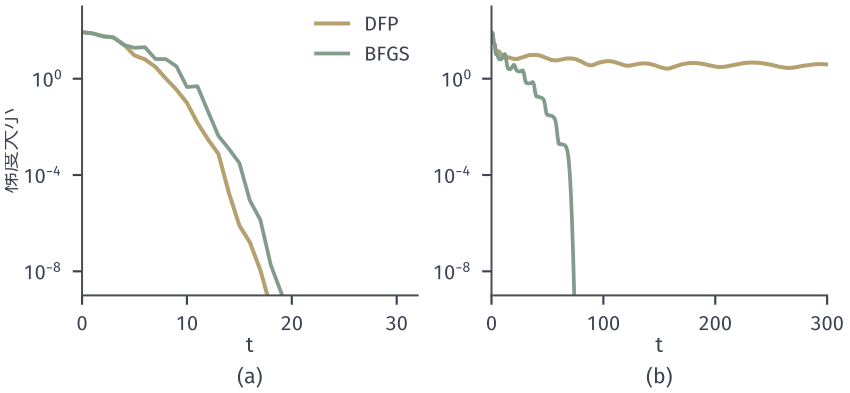


图 8.9 BFGS（绿）与 DFP（黄）的梯度大小随迭代的变化。目标是 10 维强凸函数 $\sum_i (\frac{1}{2}c_i z_i^2 + \ln\cosh z_i)$，其中 $\boldsymbol{z} = \boldsymbol{Q}\boldsymbol{x}$，$\boldsymbol{Q}$ 是固定的正交矩阵，c_i 在 $[0.1, 100]$ 上对数等距；线搜索为强 Wolfe 条件，$c_1 = 10^{-4}$，$c_2 = 0.9$。(a)$\boldsymbol{W}^{(0)} = \boldsymbol{I}$。(b)$\boldsymbol{W}^{(0)} = 10^{-3}\boldsymbol{I}$，注意横轴范围不同。

8.3 SR1

BFGS 为了保持正定，把负曲率的测量拒之门外。可是目标在某些方向确实向下弯时，这恰恰是有用的信息。这就需要回答：只用一个秩一项能否满足割线条件，这样得到的矩阵有什么长处，又有什么风险？

主要思想：只有一种秩一修正 设 $\boldsymbol{B}^{+} = \boldsymbol{B} + \sigma \boldsymbol{v}\boldsymbol{v}^{\mathsf{T}}$，其中 $\sigma = \pm 1$。记割线残差 $\boldsymbol{r} = \boldsymbol{y} - \boldsymbol{B}\boldsymbol{s}$，把割线条件写成

$$\sigma \langle \boldsymbol{v}, \boldsymbol{s} \rangle \boldsymbol{v} = \boldsymbol{r}.$$

左边是 $\boldsymbol{v}$ 的数乘，所以 $\boldsymbol{v}$ 必须平行于 $\boldsymbol{r}$。把 $\boldsymbol{v}$ 取成 $\boldsymbol{r}$ 的倍数后，σ 和倍数只有一种可能，由此得到**对称秩一更新**（symmetric rank-one update，SR1）：

$$\boldsymbol{B}^{+} = \boldsymbol{B} + \frac{\boldsymbol{r}\boldsymbol{r}^{\top}}{\langle \boldsymbol{r}, \boldsymbol{s} \rangle}, \qquad \boldsymbol{r} = \boldsymbol{y} - \boldsymbol{B}\boldsymbol{s}. \tag{8.23}$$

与第 8.2节不同，这里的更新由割线条件和“秩一”完全确定，没有选择余地。验算割线条件：$\boldsymbol{B}^{+}\boldsymbol{s} = \boldsymbol{B}\boldsymbol{s} + \boldsymbol{r} = \boldsymbol{y}$。

把同样的推导用在逆矩阵上，并记 $\boldsymbol{w} = \boldsymbol{s} - \boldsymbol{W}\boldsymbol{y}$，得到

$$\boldsymbol{W}^{+} = \boldsymbol{W} + \frac{\boldsymbol{w}\boldsymbol{w}^{\top}}{\langle \boldsymbol{w}, \boldsymbol{y} \rangle}. \tag{8.24}$$

只要 $\boldsymbol{B}$、$\boldsymbol{B}^{+}$ 都可逆，式 (8.24)的 $\boldsymbol{W}^{+}$ 就是式 (8.23)的 $\boldsymbol{B}^{+}$ 的逆，这可以用 Sherman–Morrison 公式验证。SR1 自己是自己的对偶，所以不像 BFGS 和 DFP 那样分成两种方法。

计算过程　SR1 不需要线搜索来保持什么性质，下面就用单位步长演示它。仍用贯穿例，这一次不做线搜索，每步直接走完整的 $-\boldsymbol{W}^{(t)}\boldsymbol{g}^{(t)}$。

变量

- $\boldsymbol{x}^{(t)}$、$\boldsymbol{g}^{(t)} \in \mathbb{R}^{n}$：当前点与梯度。
- $\boldsymbol{W}^{(t)} \in \mathbb{R}^{n\times n}$：对称的逆曲率近似，不要求正定。
- $\boldsymbol{s}^{(t)}$、$\boldsymbol{y}^{(t)}$：位移与梯度差；$\boldsymbol{w}^{(t)}$：式 (8.24)中逆形式的割线残差。
- $c_{\mathrm{r}} > 0$：判断分母是否过小的阈值。

初始化　选起点和对称的 $\boldsymbol{W}^{(0)}$。例中初始数据是

$$\boldsymbol{x}^{(0)} = (4, 1)^{\top}, \qquad \boldsymbol{W}^{(0)} = \boldsymbol{I}, \qquad \boldsymbol{g}^{(0)} = (8, 8)^{\top}.$$

每轮更新　对 $t = 0, 1, \ldots$ 依次执行下面的步骤，当 $\|\boldsymbol{g}^{(t)}\|_{2} \le \varepsilon$ 时停止。

1. 计算 $\boldsymbol{s}^{(t)} = -\boldsymbol{W}^{(t)}\boldsymbol{g}^{(t)}$，令 $\boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} + \boldsymbol{s}^{(t)}$，并读取 $\boldsymbol{g}^{(t+1)}$。例中第一轮得到

   $$\boldsymbol{s}^{(0)} = (-8, -8)^{\top}, \qquad \boldsymbol{x}^{(1)} = (-4, -7)^{\top}, \qquad \boldsymbol{g}^{(1)} = (-8, -56)^{\top}.$$

   目标值从 20 升到了 212，这一步在目标上是失败的，但测量仍然有用。

2. 计算 $\boldsymbol{y}^{(t)} = \boldsymbol{g}^{(t+1)} - \boldsymbol{g}^{(t)}$ 和 $\boldsymbol{w}^{(t)}$。例中第一轮得到

   $$\boldsymbol{y}^{(0)} = (-16, -64)^{\top}, \qquad \boldsymbol{w}^{(0)} = (8, 56)^{\top}, \qquad \langle \boldsymbol{w}^{(0)}, \boldsymbol{y}^{(0)} \rangle = -3712.$$

3. 若 $\langle \boldsymbol{w}^{(t)}, \boldsymbol{y}^{(t)} \rangle$ 的绝对值不小于 $c_{\mathrm{r}} \|\boldsymbol{w}^{(t)}\|_2 \|\boldsymbol{y}^{(t)}\|_2$，由式 (8.24)更新 $\boldsymbol{W}^{(t+1)}$；否则令 $\boldsymbol{W}^{(t+1)} = \boldsymbol{W}^{(t)}$。例中第一轮分母足够大，更新后得到

$$\boldsymbol{W}^{(1)} = \frac{1}{58}\begin{bmatrix} 57 & -7 \\ -7 & 9 \end{bmatrix}.$$

第二轮的位移与新点是

$$\boldsymbol{s}^{(1)} = \frac{1}{29}(32, 224)^{\top}, \qquad \boldsymbol{x}^{(2)} = \frac{1}{29}(-84, 21)^{\top} \approx (-2.897, 0.724)^{\top}.$$

梯度差和逆形式残差是

$$\boldsymbol{y}^{(1)} = \frac{1}{29}(64, 1792)^{\top}, \qquad \boldsymbol{w}^{(1)} = \frac{1344}{841}(4, -1)^{\top}.$$

分母约为 -84.64，更新量是 $-\frac{7}{232}$ 乘以 $\begin{bmatrix} 16 & -4 \\ -4 & 1 \end{bmatrix}$，于是

$$\boldsymbol{W}^{(2)} = \begin{bmatrix} 0.5 & 0 \\ 0 & 0.125 \end{bmatrix} = \boldsymbol{A}^{-1}.$$

第三轮的方向已经是 Newton 方向，一步到达解：

$$\boldsymbol{s}^{(2)} = \frac{1}{29}(84, -21)^{\top}, \qquad \boldsymbol{x}^{(3)} = \boldsymbol{0}, \qquad \boldsymbol{g}^{(3)} = \boldsymbol{0}.$$

迭代结束，最终得到解 $\boldsymbol{x}^{(3)} = \boldsymbol{0}$，用了 $n + 1 = 3$ 步。图 8.10是这条路径。

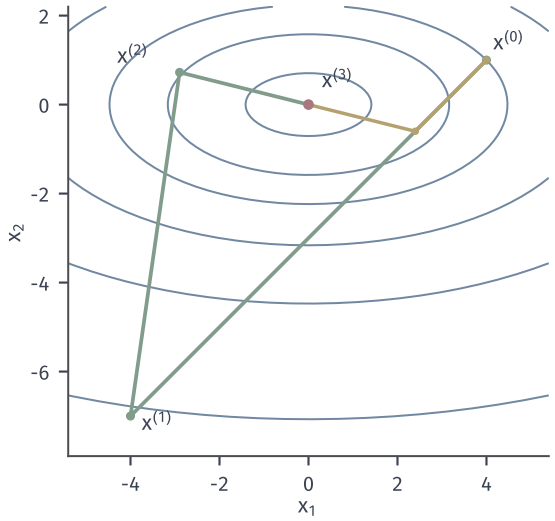


图 8.10 贯穿例上的 SR1 路径（绿）：$\boldsymbol{W}^{(0)} = \boldsymbol{I}$，每步取单位步长。第一步远远越过谷底，目标值从 20 升到 212，但两次测量足以确定 $\boldsymbol{A}$，第三步准确落在最优解（红）。黄线是精确线搜索的 BFGS 路径，用作对照。

有限步终止 这个现象对二次目标普遍成立，而且完全不依赖步长的选取。下面的定理把 BFGS 那里“两次测量都不丢失”的现象，以更强的形式写了下来。

定理 8.4 SR1 的遗传性质 设 f 是二次函数，Hessian 为对称矩阵 $\boldsymbol{A}$，于是 $\boldsymbol{y}^{(j)} = \boldsymbol{A}\boldsymbol{s}^{(j)}$。设 $\boldsymbol{B}^{(j+1)}$ 由 SR1 按式 (8.23)逐次得到，所有分母非零。则对每个 k，

$$\boldsymbol{B}^{(k)}\boldsymbol{s}^{(j)} = \boldsymbol{y}^{(j)}, \qquad j = 0, 1, \dots, k-1. \tag{8.25}$$

特别地，若 $\boldsymbol{s}^{(0)}, \dots, \boldsymbol{s}^{(n-1)}$ 线性无关，则 $\boldsymbol{B}^{(n)} = \boldsymbol{A}$。

证明 对 k 归纳。$k = 1$ 时就是割线条件。设式 (8.25)对 k 成立，并记 $\boldsymbol{r} = \boldsymbol{y}^{(k)} - \boldsymbol{B}^{(k)}\boldsymbol{s}^{(k)}$。

对 $j < k$，由归纳假设、对称性和 $\boldsymbol{y}^{(j)} = \boldsymbol{A}\boldsymbol{s}^{(j)}$，得到

$$\begin{aligned} \langle \boldsymbol{r}, \boldsymbol{s}^{(j)} \rangle &= \langle \boldsymbol{y}^{(k)}, \boldsymbol{s}^{(j)} \rangle - \langle \boldsymbol{s}^{(k)}, \boldsymbol{B}^{(k)}\boldsymbol{s}^{(j)} \rangle \\ &= \langle \boldsymbol{A}\boldsymbol{s}^{(k)}, \boldsymbol{s}^{(j)} \rangle - \langle \boldsymbol{s}^{(k)}, \boldsymbol{A}\boldsymbol{s}^{(j)} \rangle = 0. \end{aligned}$$

所以秩一修正项作用在旧位移上为零：

$$\boldsymbol{B}^{(k+1)}\boldsymbol{s}^{(j)} = \boldsymbol{B}^{(k)}\boldsymbol{s}^{(j)} + \boldsymbol{r}\,\frac{\langle \boldsymbol{r}, \boldsymbol{s}^{(j)} \rangle}{\langle \boldsymbol{r}, \boldsymbol{s}^{(k)} \rangle} = \boldsymbol{y}^{(j)}.$$

$j = k$ 时是割线条件本身，归纳完成。

$\boldsymbol{s}^{(j)}$ 线性无关时，把它们排成可逆矩阵 $\boldsymbol{S}$，式 (8.25)说明 $\boldsymbol{B}^{(n)}\boldsymbol{S} = \boldsymbol{A}\boldsymbol{S}$，右乘 $\boldsymbol{S}^{-1}$ 即得。 ∎

所以 $\boldsymbol{A}$ 可逆、$\boldsymbol{B}^{(n)}$ 之前的各步线性无关时，单位步长的 SR1 至多 $n+1$ 步到达驻点。定理没有要求 $\boldsymbol{A}$ 正定，也没有要求线搜索，这是 SR1 与 BFGS 的重要区别。

分母可能为零 SR1 的麻烦全在分母 $\langle \boldsymbol{r}, \boldsymbol{s} \rangle$ 上。若 $\boldsymbol{r} \neq \boldsymbol{0}$ 而 $\langle \boldsymbol{r}, \boldsymbol{s} \rangle = 0$，则根本不存在满足割线条件的对称秩一修正。原因是由 $\sigma\langle \boldsymbol{v}, \boldsymbol{s} \rangle \boldsymbol{v} = \boldsymbol{r}$ 与 $\boldsymbol{s}$ 作内积，得到

$$\sigma \langle \boldsymbol{v}, \boldsymbol{s} \rangle^2 = \langle \boldsymbol{r}, \boldsymbol{s} \rangle = 0.$$

于是 $\langle \boldsymbol{v}, \boldsymbol{s} \rangle = 0$，等式左边就是零向量，与 $\boldsymbol{r} \neq \boldsymbol{0}$ 矛盾。

这种情况确实会出现。取 $\boldsymbol{A} = \operatorname{diag}(2, 8)$，$\boldsymbol{B} = \operatorname{diag}(3, 7)$，$\boldsymbol{s} = (1, 1)^{\mathsf{T}}$，则

$$\boldsymbol{y} = (2, 8)^{\mathsf{T}}, \qquad \boldsymbol{r} = (-1, 1)^{\mathsf{T}}, \qquad \langle \boldsymbol{r}, \boldsymbol{s} \rangle = 0.$$

分母接近零同样有害。把 $\boldsymbol{s}$ 换成 $(1, 1+\epsilon)^{\top}$，分母是 $2\epsilon+\epsilon^2$，而 $\|\boldsymbol{r}\|_2$ 约为 $\sqrt{2}$，修正量的 Frobenius 范数约为 $1/\epsilon$。图 8.11展示了这种放大：$\epsilon = 10^{-4}$ 时修正量约为 10^4，矩阵几乎被这一次修正淹没。

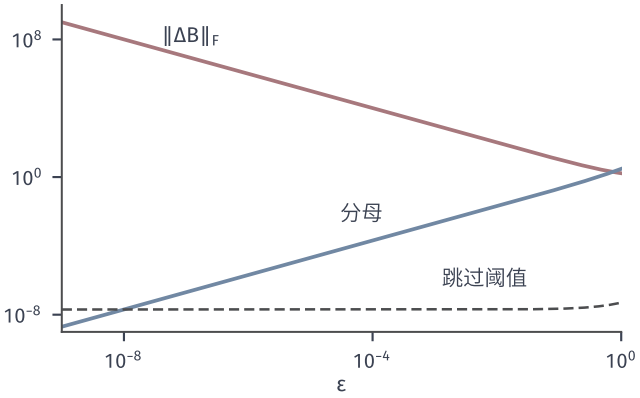


图 8.11　SR1 的分母接近零时的放大效应：$\boldsymbol{A} = \mathrm{diag}(2, 8)$，$\boldsymbol{B} = \mathrm{diag}(3, 7)$，$\boldsymbol{s} = (1, 1+\epsilon)^{\top}$。蓝线是分母 $|\langle \boldsymbol{r}, \boldsymbol{s}\rangle|$，红线是修正量 $\|\Delta \boldsymbol{B}\|_F$；虚线是取 $c_{\mathrm{r}} = 10^{-8}$ 时的跳过阈值 $c_{\mathrm{r}}\|\boldsymbol{r}\|_2\|\boldsymbol{s}\|_2$，分母低于它就不更新。

所以 SR1 配有跳过规则，这就是计算过程第三步的判断，直接形式下写成

$$|\langle \boldsymbol{r}, \boldsymbol{s}\rangle| \geq c_{\mathrm{r}}\|\boldsymbol{r}\|_2\|\boldsymbol{s}\|_2, \tag{8.26}$$

通常取 $c_{\mathrm{r}} = 10^{-8}$。不满足时保持 $\boldsymbol{B}^{+} = \boldsymbol{B}$。

式 (8.26)中的角度形式比绝对阈值合理：它问的是 $\boldsymbol{r}$ 与 $\boldsymbol{s}$ 是否几乎垂直，与两个向量的长度无关。跳过很少发生，因为分母近零需要 $\boldsymbol{r}$ 恰好几乎垂直于 $\boldsymbol{s}$。

SR1 通常不保持正定　BFGS 的更新中，分母 $\langle \boldsymbol{s}, \boldsymbol{y}\rangle$ 与修正项的符号都受控制。SR1 的分母可正可负，修正项的符号跟着变，所以正定矩阵可能变成不定矩阵，即使目标强凸。

取贯穿例的目标，$\boldsymbol{x}^{(0)} = (-4, -0.5)^{\top}$，$\boldsymbol{B}^{(0)} = 4\boldsymbol{I}$，单位步长。这时

$$\boldsymbol{g}^{(0)} = (-8, -4)^{\top}, \qquad \boldsymbol{s}^{(0)} = (2, 1)^{\top}, \qquad \boldsymbol{y}^{(0)} = (4, 8)^{\top}.$$

$\boldsymbol{B}^{(0)}\boldsymbol{s}^{(0)} = (8, 4)^{\top}$，所以残差和分母是

$$\boldsymbol{r} = (-4, 4)^{\top}, \qquad \langle \boldsymbol{r}, \boldsymbol{s}^{(0)}\rangle = -4.$$

代入式 (8.23)，得到

$$\boldsymbol{B}^{(1)} = \begin{bmatrix} 0 & 4 \\ 4 & 0 \end{bmatrix}.$$

它的特征值是 ± 4，不定。验算割线条件：$\boldsymbol{B}^{(1)}\boldsymbol{s}^{(0)} = (4, 8)^{\top} = \boldsymbol{y}^{(0)}$。

新点是 $\boldsymbol{x}^{(1)} = (-2, 0.5)^{\top}$，梯度 $\boldsymbol{g}^{(1)} = (-4, 4)^{\top}$。若仍然用公式 (8.3)算方向，得到

$$\boldsymbol{d} = -\big(\boldsymbol{B}^{(1)}\big)^{-1}\boldsymbol{g}^{(1)} = (-1, 1)^{\top}, \qquad \langle \boldsymbol{g}^{(1)}, \boldsymbol{d}\rangle = 8 > 0.$$

这是一个上升方向。$\boldsymbol{d}$ 是模型的驻点，但模型不定，驻点是鞍点而不是极小点。沿它走一步，目标从 5 升到 18。第 8.1节的下降论证依赖 $\boldsymbol{W}$ 正定，这里前提已经不成立，所以不能把 BFGS 方向的下降分析搬过来。

不定模型与信赖域 不定的 $\boldsymbol{B}$ 并非无用，用错的只是“跑到模型驻点”这个做法。模型 $m(\boldsymbol{p})$ 在 $\boldsymbol{p}$ 的某些方向向下弯，这时它没有极小点，但在一个有界的范围内它有。第 9章的信赖域方法正是如此：只在以当前点为中心、半径为 Δ 的球内最小化模型，并用实际下降检验这个候选步。

继续上面的例子，取 $\Delta = 1$。$\boldsymbol{B}^{(1)}$ 的负特征值 -4 对应单位特征向量 $\boldsymbol{v} = (1, -1)^{\top}/\sqrt{2}$，而 $\boldsymbol{g}^{(1)} = -4\sqrt{2}\,\boldsymbol{v}$ 恰好全部落在这个方向上。沿 $\boldsymbol{p} = \beta\boldsymbol{v}$，模型的变化量是

$$m(\beta\boldsymbol{v}) - m(\boldsymbol{0}) = -4\sqrt{2}\,\beta - 2\beta^{2}.$$

在 $|\beta| \le 1$ 上它在 $\beta = 1$ 处最小，所以候选步是

$$\boldsymbol{p}_{\Delta} = \frac{1}{\sqrt{2}}(1, -1)^{\top}.$$

它是下降方向，因为与梯度的内积是 $-4\sqrt{2} < 0$。沿它走一步，目标从 5 降到约 1.843。图 8.12比较了两个候选步。

8.1 割线条件
8.2 DFP 与 BFGS
8.3 SR1
8.4 L-BFGS
8.5 收敛与计算成本
8.6 本章小结

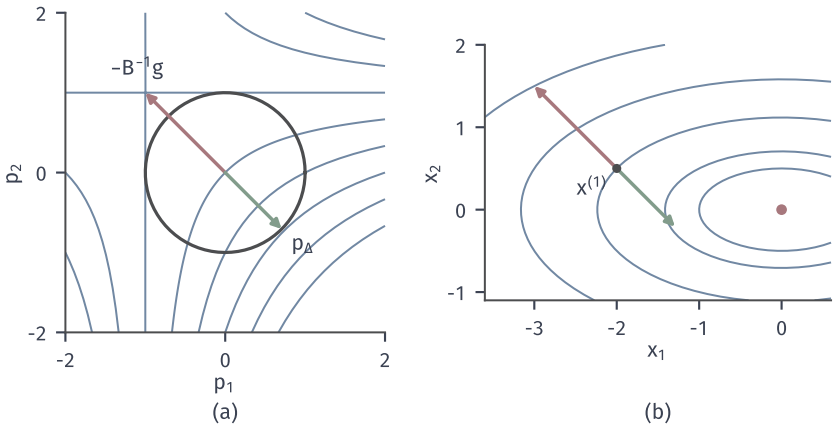


图 8.12 不定模型下的两个候选步，$\boldsymbol{B}=\begin{bmatrix}0 & 4\\ 4 & 0\end{bmatrix}$，$\boldsymbol{g}=(-4,4)^{\mathsf{T}}$，圆的半径为 1。(a) 蓝线是模型 $m(\boldsymbol{p})$ 的等值线，呈鞍形。红箭头是模型的驻点 $-\boldsymbol{B}^{-1}\boldsymbol{g}$，绿箭头是圆内模型的极小点。(b) 同样的两步放到真实目标 $x_1^2+4x_2^2$ 的等高线上，红步使目标上升，绿步使目标下降。

这也解释了 SR1 和 BFGS 的分工。BFGS 的矩阵总是正定的，方向一定下降，配线搜索很自然；但它看不到负曲率，也只有测量满足曲率条件才能更新。SR1 能记录负曲率，在二次目标上对步长没有要求，但需要有界的模型来消化不定性。

比较项	BFGS	SR1
修正的秩	二	一
更新的前提	曲率条件	分母不过小
正定性	保持	通常不保持
负曲率信息	不能表示	可以表示
配套的全局化手段	Wolfe 线搜索	信赖域

表 8.3 BFGS 与 SR1 的对比。

8.4 L-BFGS

BFGS 不必解方程，但仍要保存一个 $n\times n$ 的稠密矩阵。$n=10^6$ 时这需要约 10^{12} 个元素的存储，通常根本放不下。不保存矩阵，能否仍然算出 $\boldsymbol{W}^{(t)}\boldsymbol{g}^{(t)}$？

主要思想：只保留最近的测量 BFGS 的 $\boldsymbol{W}^{(t)}$ 完全由 $\boldsymbol{W}^{(0)}$ 和所有的 $(\boldsymbol{s}^{(j)},\boldsymbol{y}^{(j)})$ 决定。旧测量在非二次目标上已经过时，于是**有限记忆 BFGS**（limited-memory BFGS，L-BFGS）只保留最近 r 对，r 称为记忆长度，常取 3 到 30。

存储从约 $n^2/2$ 个数降到 $2rn$ 个数。每一轮都重新从一个简单的初始矩阵 $\gamma^{(t)}\boldsymbol{I}$ 出发，把这 r 对依次用式 (8.17)更新一遍，得到的矩阵就是这一轮的 $\boldsymbol{W}^{(t)}$。

记下面 r 次更新的中间矩阵为 $\boldsymbol{W}_{[j]}$，下标 j 从 $t-r$ 走到 t。起点和递推是

$$\boldsymbol{W}_{[t-r]} = \gamma^{(t)}\boldsymbol{I}, \qquad \boldsymbol{W}_{[j+1]} = \big(\boldsymbol{V}^{(j)}\big)^{\top}\boldsymbol{W}_{[j]}\boldsymbol{V}^{(j)} + \rho^{(j)}\boldsymbol{s}^{(j)}\big(\boldsymbol{s}^{(j)}\big)^{\top}, \tag{8.27}$$

其中 $\boldsymbol{V}^{(j)}$ 由第 j 对向量按定理 8.2的方式构成，最后 $\boldsymbol{W}^{(t)} = \boldsymbol{W}_{[t]}$。显式写出这些矩阵要 $O(n^2)$ 的存储，我们其实只需要它乘一个向量的结果。

主要思想：两层递推 令 $\boldsymbol{q}_{[t]} = \boldsymbol{g}^{(t)}$，想算 $\boldsymbol{W}_{[t]}\boldsymbol{q}_{[t]}$。把递推 (8.27)作用在向量 $\boldsymbol{q}_{[j+1]}$ 上，先算出向右侧的两个量：

$$\xi^{(j)} = \rho^{(j)}\langle \boldsymbol{s}^{(j)}, \boldsymbol{q}_{[j+1]}\rangle, \qquad \boldsymbol{q}_{[j]} = \boldsymbol{V}^{(j)}\boldsymbol{q}_{[j+1]} = \boldsymbol{q}_{[j+1]} - \xi^{(j)}\boldsymbol{y}^{(j)}.$$

于是一次更新对向量的作用可以写成

$$\boldsymbol{W}_{[j+1]}\boldsymbol{q}_{[j+1]} = \big(\boldsymbol{V}^{(j)}\big)^{\top}\boldsymbol{W}_{[j]}\boldsymbol{q}_{[j]} + \xi^{(j)}\boldsymbol{s}^{(j)}.$$

右端的 $\boldsymbol{W}_{[j]}\boldsymbol{q}_{[j]}$ 是同样形式、但下标小一的问题。所以计算分两层：第一层让 j 从 $t-1$ 递减到 $t-r$，把 $\boldsymbol{q}$ 一路算下去，记下所有 $\xi^{(j)}$。

第一层走到底时，最内层的矩阵是 $\gamma^{(t)}\boldsymbol{I}$，令 $\boldsymbol{z}_{[t-r]} = \gamma^{(t)}\boldsymbol{q}_{[t-r]}$。记 $\boldsymbol{z}_{[j]} = \boldsymbol{W}_{[j]}\boldsymbol{q}_{[j]}$，把 $\boldsymbol{V}^{(j)}$ 的转置展开，得到第二层的递推：

$$\eta^{(j)} = \rho^{(j)}\langle \boldsymbol{y}^{(j)}, \boldsymbol{z}_{[j]}\rangle, \qquad \boldsymbol{z}_{[j+1]} = \boldsymbol{z}_{[j]} + \big(\xi^{(j)} - \eta^{(j)}\big)\boldsymbol{s}^{(j)}. \tag{8.28}$$

第二层让 j 从 $t-r$ 递增到 $t-1$，最后的 $\boldsymbol{z}_{[t]}$ 就是 $\boldsymbol{W}^{(t)}\boldsymbol{g}^{(t)}$。这就是**双循环递推**（two-loop recursion），图 8.13是它的结构。

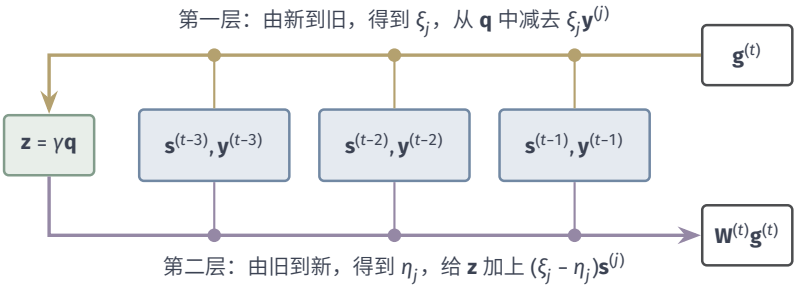


图 8.13 L-BFGS 的双循环递推，$r = 3$。蓝框是保存的三对向量。第一层（黄）从梯度出发，由最新一对走到最旧一对；中间乘初始矩阵 $\gamma\boldsymbol{I}$（绿框）；第二层（紫）由最旧一对走回最新一对，输出 $\boldsymbol{W}^{(t)}\boldsymbol{g}^{(t)}$。全程只有向量内积和向量加法。

每一层对每对向量做一次内积和一次向量加法，再加上中间的缩放，每个方向的运算量约为 $(4r+1)n$ 次乘法。矩阵本身从未出现。

主要思想：初始缩放　最内层的矩阵决定了双循环不了解的那些方向上的尺度。L-BFGS 一般取

$$\gamma^{(t)} = \frac{\langle \boldsymbol{s}^{(t-1)}, \boldsymbol{y}^{(t-1)} \rangle}{\langle \boldsymbol{y}^{(t-1)}, \boldsymbol{y}^{(t-1)} \rangle}. \tag{8.29}$$

它的含义可以由式(8.5)看出。设平均 Hessian 正定，并把 $(\bar{\boldsymbol{H}}^{(t-1)})^{1/2}\boldsymbol{s}^{(t-1)}$ 记作 $\boldsymbol{z}$，则

$$\frac{1}{\gamma^{(t)}} = \frac{\boldsymbol{z}^{\top}\bar{\boldsymbol{H}}^{(t-1)}\boldsymbol{z}}{\boldsymbol{z}^{\top}\boldsymbol{z}}.$$

所以 $1/\gamma^{(t)}$ 是平均 Hessian 的一个 Rayleigh 商，落在其最小与最大特征值之间，是目标曲率的一个合理的标量估计。

主要思想：曲率检查　与完整 BFGS 一样，存入的 $(\boldsymbol{s}^{(j)}, \boldsymbol{y}^{(j)})$ 必须满足 $\langle \boldsymbol{s}^{(j)}, \boldsymbol{y}^{(j)} \rangle > 0$，否则式(8.27)不再保证正定，算出的方向可能不下降。Wolfe 线搜索使这一点自动成立。只用回溯时，要加上跳过规则：满足式(8.21)的这一对不存入，窗口保持原样。

计算过程　下面用贯穿例演示 $r = 2$ 的 L-BFGS。为了不让第一层的系数因为正交性而消失，第一步取 $\alpha^{(0)} = 1/8$ 而不是精确步长，以后都用单位步长；这些步长都满足 $c_1 = 10^{-4}$、$c_2 = 0.9$ 的 Wolfe 条件。

变量

- $\boldsymbol{x}^{(t)}$、$\boldsymbol{g}^{(t)} \in \mathbb{R}^n$：当前点与梯度。
- 窗口：最多 r 组 $(\boldsymbol{s}^{(j)}, \boldsymbol{y}^{(j)}, \rho^{(j)})$，$\boldsymbol{s}^{(j)}, \boldsymbol{y}^{(j)} \in \mathbb{R}^n$，$\rho^{(j)}$ 是标量，从旧到新排列。
- 第一层的向量 $\boldsymbol{q} \in \mathbb{R}^n$ 和系数 $\xi^{(j)}$；第二层的向量 $\boldsymbol{z} \in \mathbb{R}^n$ 和系数 $\eta^{(j)}$。
- $\gamma^{(t)} > 0$：初始矩阵的缩放。

初始化　选起点，窗口置空。窗口为空时取 $\gamma^{(0)} = 1$，方向就是负梯度。例中第一轮的数据是

$$\boldsymbol{x}^{(0)} = (4, 1)^{\top}, \qquad \boldsymbol{g}^{(0)} = (8, 8)^{\top}, \qquad \boldsymbol{d}^{(0)} = (-8, -8)^{\top}.$$

取 $\alpha^{(0)} = 1/8$，走完后有

$$\boldsymbol{x}^{(1)} = (3, 0)^{\top}, \qquad \boldsymbol{g}^{(1)} = (6, 0)^{\top}.$$

第一对测量及其 ρ 是

$$\boldsymbol{s}^{(0)} = (-1, -1)^{\top}, \qquad \boldsymbol{y}^{(0)} = (-2, -8)^{\top}, \qquad \rho^{(0)} = 0.1.$$

每轮更新 对 $t = 1, 2, \ldots$ 依次执行下面的步骤，当 $\|\boldsymbol{g}^{(t)}\|_2 \le \varepsilon$ 时停止。

1. 第一层，令 $\boldsymbol{q} = \boldsymbol{g}^{(t)}$，对窗口中的 j 由新到旧，依次计算

   $$\xi^{(j)} = \rho^{(j)} \langle \boldsymbol{s}^{(j)}, \boldsymbol{q} \rangle, \qquad \boldsymbol{q} \leftarrow \boldsymbol{q} - \xi^{(j)} \boldsymbol{y}^{(j)}.$$

   例中 $t = 1$ 时窗口只有一对，结果是

   $$\xi^{(0)} = -0.6, \qquad \boldsymbol{q} = (4.8, -4.8)^{\top}.$$

2. 由式 (8.29)计算 $\gamma^{(t)}$，并令 $\boldsymbol{z} = \gamma^{(t)} \boldsymbol{q}$。例中 $t = 1$ 时 $\langle \boldsymbol{y}^{(0)}, \boldsymbol{y}^{(0)} \rangle = 68$，于是

   $$\gamma^{(1)} = \frac{10}{68} = \frac{5}{34}, \qquad \boldsymbol{z} \approx (0.7059, -0.7059)^{\top}.$$

3. 第二层，对窗口中的 j 由旧到新，按式 (8.28)更新 $\boldsymbol{z}$。例中 $t = 1$ 时得到

   $$\eta^{(0)} \approx 0.4235, \qquad \boldsymbol{z} \approx (1.7294, 0.3176)^{\top}.$$

4. 令 $\boldsymbol{d}^{(t)} = -\boldsymbol{z}$，线搜索后得到新点和新梯度。例中 $t = 1$ 时取 $\alpha^{(1)} = 1$，结果是

   $$\boldsymbol{d}^{(1)} \approx (-1.7294, -0.3176)^{\top}, \qquad \boldsymbol{x}^{(2)} \approx (1.2706, -0.3176)^{\top}.$$

5. 计算 $\boldsymbol{s}^{(t)}$、$\boldsymbol{y}^{(t)}$ 和 $\rho^{(t)}$，曲率检查通过后存入窗口；若窗口超过 r 对，丢弃最旧的一对。例中 $t = 1$ 时

   $$\boldsymbol{y}^{(1)} \approx (-3.4588, -2.5412)^{\top}, \qquad \rho^{(1)} \approx 0.14730.$$

   窗口现在有两对，还没有超过 $r = 2$。

   $t = 2$ 时窗口有两对，能看到完整的双循环。此时的梯度是

   $$\boldsymbol{g}^{(2)} \approx (2.5412, -2.5412)^{\top}.$$

第一层由新到旧的两次计算是

$$
\begin{aligned}
&j=1:\quad \xi^{(1)} \approx -0.5284,\quad \boldsymbol{q} \approx (0.7134, -3.8840)^{\top},\\
&j=0:\quad \xi^{(0)} \approx 0.3171,\quad \boldsymbol{q} \approx (1.3475, -1.3475)^{\top}.
\end{aligned}
$$

中间的缩放使用最新一对，结果是

$$
\gamma^{(2)} \approx 0.36854, \qquad \boldsymbol{z} \approx (0.4966, -0.4966)^{\top}.
$$

第二层由旧到新的两次计算是

$$
\begin{aligned}
&j=0:\quad \eta^{(0)} \approx 0.2980,\quad \boldsymbol{z} \approx (0.4775, -0.5157)^{\top},\\
&j=1:\quad \eta^{(1)} \approx -0.0503,\quad \boldsymbol{z} \approx (1.3045, -0.3638)^{\top}.
\end{aligned}
$$

取单位步长，新的点是

$$
\boldsymbol{d}^{(2)} \approx (-1.3045, 0.3638)^{\top}, \qquad \boldsymbol{x}^{(3)} \approx (-0.0339, 0.0462)^{\top}.
$$

$t=3$ 时窗口超过 $r=2$，$\boldsymbol{s}^{(0)}$、$\boldsymbol{y}^{(0)}$ 被丢弃。后续各轮的结果列在表 8.4中。取 $\varepsilon = 10^{-3}$，在 $t=7$ 时停止，表中最后一行就是最终得到的点。

t	$\boldsymbol{x}^{(t)}$（近似）	$\lVert \boldsymbol{g}^{(t)} \rVert_2$	$f(\boldsymbol{x}^{(t)})$
0	$(4,\ 1)$	11.31	20
1	$(3,\ 0)$	6	9
2	$(1.2706,\ -0.3176)$	3.594	2.018
3	$(-0.0339,\ 0.0462)$	0.3755	9.7×10^{-3}
4	$(-0.0150,\ -0.0134)$	0.1115	9.4×10^{-4}
5	$(-0.0012,\ -0.0001)$	2.4×10^{-3}	1.4×10^{-6}
6	$(-0.0004,\ 0.0001)$	1.1×10^{-3}	1.8×10^{-7}
7	$(0.000005,\ -0.000005)$	4.1×10^{-5}	1.2×10^{-10}

表 8.4　贯穿例上 $r=2$ 的 L-BFGS 各轮结果，$\alpha^{(0)}=1/8$，其余各轮 $\alpha^{(t)}=1$。

和完整 BFGS 的两步终止比较，这里用了七步，尽管 r 已经等于变量个数 n。差别来自两处：步长不是精确的，而且每一轮都从 $\gamma^{(t)}\boldsymbol{I}$ 重新开始，矩阵不再累积。

窗口尚未被填满时，只有初始矩阵不同；若初始矩阵也取同一个 $\gamma\boldsymbol{I}$，L-BFGS 与完整 BFGS 算出的方向完全相同。两者的差别从第一次丢弃旧测量开始。

记忆长度的影响 图 8.14在一个 200 维、系数跨越六个数量级的强凸目标上比较不同的 r。迭代数随 r 增大而减少，但下降缓慢：r 从 1 增加到 100，迭代数从 429 降到 218，而方向运算量大约增加 50 倍。

因此 r 的选择取决于梯度和方向计算哪个贵：梯度贵时，多用一点记忆来节省梯度是值得的；梯度便宜时，小的 r 更省。图中的数据只说明这一个目标的情况，不是普遍的定量规律。

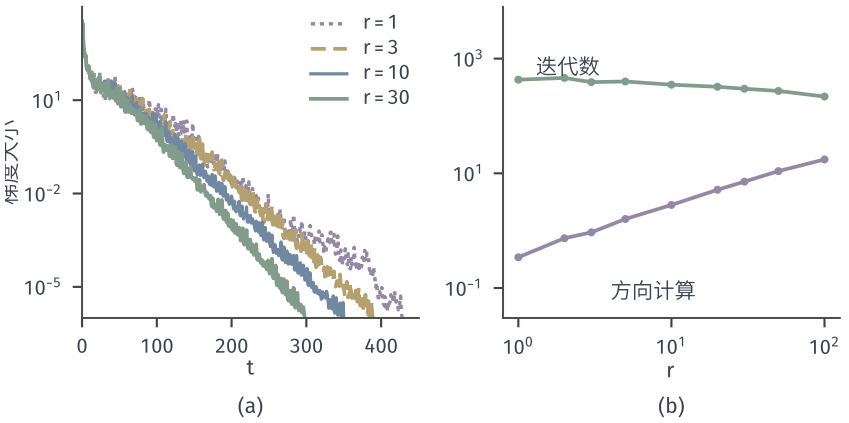


图 8.14 记忆长度的影响。目标是 200 维的 $\sum_i (\frac{1}{2} c_i z_i^2 + \ln\cosh z_i)$，$\boldsymbol{z} = \boldsymbol{Q}\boldsymbol{x}$，$\boldsymbol{Q}$ 是固定的正交矩阵，c_i 在 $[10^{-3}, 10^{3}]$ 上对数等距，强 Wolfe 线搜索，$c_2 = 0.9$。(a) 不同 r 下的梯度大小。(b) 达到梯度大小 10^{-6} 的迭代数（绿）和这些迭代中方向计算的总乘法次数（紫，单位百万次，按每步 $4rn$ 估算）。

初始缩放的影响 图 8.15比较有缩放 (8.29)和始终用 $\gamma = 1$ 的两种做法，记忆长度都是 $r = 10$，目标的曲率整体偏大。

没有缩放时，单位矩阵相对于真实曲率过大，方向过长，线搜索不得不反复收缩，292 轮迭代共用了 5012 次函数和梯度计算。有缩放时只用 130 轮迭代和 268 次计算。这个对比说明，在大尺度问题上，第 8.1节“优先试单位步长”的策略依赖矩阵有正确的尺度。

8.1 割线条件
8.2 DFP 与 BFGS
8.3 SR1
8.4 L-BFGS
8.5 收敛与计算成本
8.6 本章小结

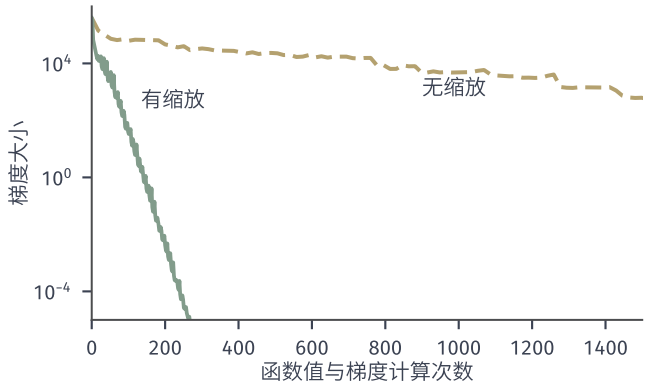


图 8.15 初始缩放的影响：$r = 10$，目标是 $n = 200$ 的旋转 $\ln\cosh$ 函数（c_i 在 $[0.01, 100]$ 上对数等距）再乘以 1000，强 Wolfe 线搜索。绿线取式 (8.29)的缩放，黄虚线始终取 $\gamma = 1$。横轴是函数值与梯度的计算次数，纵轴是梯度大小。

8.5 收敛与计算成本

前面各节展示了许多好现象，但例子都很小。于是要问：这些方法在什么条件下能保证什么？答案要分开说，因为不同的更新规则、线搜索和目标类型，对应的结论强弱不同。

全节的基本假设是：f 二阶连续可微，存在 $0 < \mu \le L$ 使 $\mu \boldsymbol{I} \preceq \nabla^2 f(\boldsymbol{x}) \preceq L\boldsymbol{I}$ 对所有 $\boldsymbol{x}$ 成立，$\boldsymbol{x}^\star$ 是唯一最优解。需要放宽时会明确说明。

一步下降与方向角 先把线搜索的贡献算清楚。记 $\theta^{(t)}$ 为 $\boldsymbol{d}^{(t)}$ 与 $-\boldsymbol{g}^{(t)}$ 的夹角，

$$\cos\theta^{(t)} = \frac{-\langle \boldsymbol{g}^{(t)}, \boldsymbol{d}^{(t)} \rangle}{\|\boldsymbol{g}^{(t)}\|_2 \|\boldsymbol{d}^{(t)}\|_2}. \tag{8.30}$$

方向越接近负梯度，$\cos\theta^{(t)}$ 越接近 1；方向几乎与梯度垂直时，它接近 0，再好的步长也下降有限。

引理 8.5 Wolfe 线搜索的一步下降 设 ∇f 是 L-Lipschitz 的，$\boldsymbol{d}^{(t)}$ 是下降方向，$\alpha^{(t)}$ 满足式 (8.13)。则

$$f(\boldsymbol{x}^{(t+1)}) \le f(\boldsymbol{x}^{(t)}) - \frac{c_1(1-c_2)}{L}\cos^2\theta^{(t)} \|\boldsymbol{g}^{(t)}\|_2^2. \tag{8.31}$$

证明 省略上标。由第二条 Wolfe 不等式和梯度的 Lipschitz 性，得到

$$(c_2 - 1)\langle \boldsymbol{g}, \boldsymbol{d} \rangle \le \langle \boldsymbol{g}^+ - \boldsymbol{g}, \boldsymbol{d} \rangle \le \alpha L \|\boldsymbol{d}\|_2^2.$$

这给出步长的下界：

$$\alpha \geq \frac{(1-c_2)|\langle \boldsymbol{g}, \boldsymbol{d} \rangle|}{L\|\boldsymbol{d}\|_2^2}.$$

把它代入第一条 Wolfe 不等式，并用式 (8.30)，得到

$$f(\boldsymbol{x}^+) \leq f(\boldsymbol{x}) - c_1\alpha|\langle \boldsymbol{g}, \boldsymbol{d} \rangle| \leq f(\boldsymbol{x}) - \frac{c_1(1-c_2)}{L} \cdot \frac{\langle \boldsymbol{g}, \boldsymbol{d} \rangle^2}{\|\boldsymbol{d}\|_2^2},$$

最后一个分式等于 $\cos^2\theta\|\boldsymbol{g}\|_2^2$。 ■

把式 (8.31)对 t 求和，并用 f 有下界，就得到称为Zoutendijk 条件（Zoutendijk condition）的结论 $\sum_t \cos^2\theta^{(t)}\|\boldsymbol{g}^{(t)}\|_2^2 < \infty$。所以只要 $\cos\theta^{(t)}$ 不趋于零，梯度就要趋于零。全局收敛的问题变成：方向角能不能控制住？

BFGS 的全局收敛 BFGS 的矩阵可能很差，方向可能很偏。下面的定理说，只要目标强凸，差的方向不可能一直出现。证明的工具是一个衡量矩阵“病态程度”的势函数，这也就是自校正的数学内容。

定理 8.6 BFGS 在强凸目标上的全局收敛 设 f 满足本节的基本假设，$\boldsymbol{B}^{(0)} \succ \boldsymbol{0}$，步长满足 Wolfe 条件 (8.13)，所有 $\boldsymbol{g}^{(t)} \neq \boldsymbol{0}$。则 BFGS 的迭代点满足

$$\lim_{t\to\infty} \boldsymbol{x}^{(t)} = \boldsymbol{x}^\star. \tag{8.32}$$

证明 由式 (8.20)和定理 8.3，所有 $\boldsymbol{B}^{(t)}$ 正定。定义势函数

$$\psi(\boldsymbol{B}) = \operatorname{tr}\boldsymbol{B} - \ln\det\boldsymbol{B} = \sum_{i=1}^{n}(\lambda_i - \ln\lambda_i),$$

其中 λ_i 是 $\boldsymbol{B}$ 的特征值。因为 $\lambda - \ln\lambda \geq 1$，所以 $\psi(\boldsymbol{B}) > 0$。它同时惩罚过大和过小的特征值。

第一步，估计测量的尺度。省略上标，由式 (8.5)，并令 $\boldsymbol{z} = \bar{\boldsymbol{H}}^{1/2}\boldsymbol{s}$，得到

$$\frac{\langle \boldsymbol{s}, \boldsymbol{y} \rangle}{\langle \boldsymbol{s}, \boldsymbol{s} \rangle} \geq \mu, \qquad \frac{\langle \boldsymbol{y}, \boldsymbol{y} \rangle}{\langle \boldsymbol{s}, \boldsymbol{y} \rangle} = \frac{\boldsymbol{z}^\top \bar{\boldsymbol{H}}\boldsymbol{z}}{\boldsymbol{z}^\top\boldsymbol{z}} \leq L.$$

第二步，计算迹和行列式的变化。对式 (8.15)取迹，得到

$$\operatorname{tr}\boldsymbol{B}^+ = \operatorname{tr}\boldsymbol{B} - \frac{\|\boldsymbol{B}\boldsymbol{s}\|_2^2}{\boldsymbol{s}^\top\boldsymbol{B}\boldsymbol{s}} + \frac{\|\boldsymbol{y}\|_2^2}{\langle \boldsymbol{s}, \boldsymbol{y} \rangle}.$$

行列式把 $\boldsymbol{B}$ 提出来，写成

$$\det \boldsymbol{B}^{+} = \det \boldsymbol{B} \cdot \det\!\Big(\boldsymbol{I} - \frac{\boldsymbol{s}(\boldsymbol{B}\boldsymbol{s})^{\top}}{\boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s}} + \rho\, \boldsymbol{W}\boldsymbol{y}\boldsymbol{y}^{\top}\Big).$$

括号内是 $\boldsymbol{I} + \boldsymbol{U}\boldsymbol{C}^{\top}$ 的形式，其中 $\boldsymbol{U}$ 的两列是 $-\boldsymbol{s}/(\boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s})$ 与 $\rho\boldsymbol{W}\boldsymbol{y}$，$\boldsymbol{C}$ 的两列是 $\boldsymbol{B}\boldsymbol{s}$ 与 $\boldsymbol{y}$。由行列式的恒等式（交换乘积因子，维数从 n 降到 2），$\boldsymbol{I} + \boldsymbol{U}\boldsymbol{C}^{\top}$ 与 $\boldsymbol{I} + \boldsymbol{C}^{\top}\boldsymbol{U}$ 的行列式相同。沿用第 8.2节的曲率比 τ，则

$$\boldsymbol{I} + \boldsymbol{C}^{\top}\boldsymbol{U} = \begin{bmatrix} 0 & 1 \\ -\tau & 1 + \rho\, \boldsymbol{y}^{\top}\boldsymbol{W}\boldsymbol{y} \end{bmatrix},$$

这个矩阵的行列式是 τ，因此

$$\det \boldsymbol{B}^{+} = \det \boldsymbol{B} \cdot \frac{\langle \boldsymbol{s}, \boldsymbol{y} \rangle}{\boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s}}.$$

第三步，用方向角重写。由 $\boldsymbol{B}\boldsymbol{d} = -\boldsymbol{g}$ 和 $\boldsymbol{s} = \alpha\boldsymbol{d}$，式 (8.30)的夹角满足

$$\cos\theta = \frac{\boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s}}{\|\boldsymbol{s}\|_2 \|\boldsymbol{B}\boldsymbol{s}\|_2}.$$

再引入三个比值：

$$q = \frac{\boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s}}{\langle \boldsymbol{s}, \boldsymbol{s} \rangle}, \qquad m_{\mathrm{c}} = \frac{\langle \boldsymbol{s}, \boldsymbol{y} \rangle}{\langle \boldsymbol{s}, \boldsymbol{s} \rangle}, \qquad M_{\mathrm{c}} = \frac{\langle \boldsymbol{y}, \boldsymbol{y} \rangle}{\langle \boldsymbol{s}, \boldsymbol{y} \rangle}.$$

于是迹和行列式公式中的两个量可以写成

$$\frac{\|\boldsymbol{B}\boldsymbol{s}\|_2^2}{\boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s}} = \frac{q}{\cos^2\theta}, \qquad \frac{\langle \boldsymbol{s}, \boldsymbol{y} \rangle}{\boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s}} = \frac{m_{\mathrm{c}}}{q}.$$

把第二步的结果代入 ψ，整理得到

$$\psi(\boldsymbol{B}^{+}) = \psi(\boldsymbol{B}) + (M_{\mathrm{c}} - \ln m_{\mathrm{c}} - 1) + \Big[1 - \frac{q}{\cos^2\theta} + \ln \frac{q}{\cos^2\theta}\Big] + \ln\cos^2\theta.$$

方括号非正，因为 $1 - v + \ln v \le 0$ 对 $v > 0$ 成立。令 $c = \max\{L - \ln\mu - 1,\, 1\} > 0$，由第一步，

$$\psi(\boldsymbol{B}^{(t+1)}) \le \psi(\boldsymbol{B}^{(0)}) + c(t+1) + \sum_{j=0}^{t} \ln\cos^2\theta^{(j)}.$$

第四步，反证。设 $\cos\theta^{(t)} \to 0$，则存在 t_1，当 $j > t_1$ 时 $\ln\cos^2\theta^{(j)} < -2c$。对 $t > t_1$，上式右端不超过

$$\psi(\boldsymbol{B}^{(0)}) + c(t+1) + \sum_{j \le t_1} \ln\cos^2\theta^{(j)} - 2c(t - t_1).$$

它随 t 线性趋于 $-\infty$，与 $\psi > 0$ 矛盾。所以存在 $\delta > 0$ 和子列使 $\cos\theta^{(t)} \geq \delta$。

第五步，收敛。对引理 8.5求和，得到 Zoutendijk 条件，所以沿这个子列 $\|\boldsymbol{g}^{(t)}\|_2 \to 0$。第 1章的误差换算给出下面两个不等式：

$$f(\boldsymbol{x}) - f^\star \leq \frac{\|\nabla f(\boldsymbol{x})\|_2^2}{2\mu}, \qquad \frac{\mu}{2}\|\boldsymbol{x} - \boldsymbol{x}^\star\|_2^2 \leq f(\boldsymbol{x}) - f^\star.$$

前一个说明沿子列 $f(\boldsymbol{x}^{(t)}) \to f^\star$。

$f(\boldsymbol{x}^{(t)})$ 单调，于是整个序列的目标值都收敛到 $f^\star$。再由后一个不等式，迭代点收敛到 $\boldsymbol{x}^\star$。 ■

用贯穿例的 BFGS（$\boldsymbol{B}^{(0)} = \boldsymbol{I}$，精确线搜索）核对一下这个公式。三个矩阵的 ψ 值是

$$\psi(\boldsymbol{B}^{(0)}) = 2, \qquad \psi(\boldsymbol{B}^{(1)}) = 7.8 - \ln 5 \approx 6.191,$$
$$\psi(\boldsymbol{B}^{(2)}) = 10 - \ln 16 \approx 7.227.$$

第一次更新 $\cos\theta^{(0)} = 1$、$q = 1$，方括号与最后的对数都是零，增量全部来自尺度项。按定理证明中的记号，$M_{\mathrm{c}} = 6.8$，$m_{\mathrm{c}} = 5$，于是

$$\psi(\boldsymbol{B}^{(1)}) - \psi(\boldsymbol{B}^{(0)}) = 6.8 - \ln 5 - 1 \approx 4.191.$$

第二次更新的方向角满足 $\cos^2\theta^{(1)} \approx 0.735$，此时 $q/\cos^2\theta^{(1)} = 1$，方括号仍是零。尺度项是 $3.2 - \ln 2.353 - 1 \approx 1.344$，而 $\ln\cos^2\theta^{(1)} \approx -0.308$，两者之和与 ψ 的实际增量 1.036 一致。

定理的证明解释了自校正：ψ 每一步至多增加一个常数，而每次方向偏得厉害都要付出 $\ln\cos^2\theta$ 这一项的大幅减少，方向不可能一直偏。证明中的第二步用到了 BFGS 特有的迹和行列式公式，不能搬给 DFP；我们也不声称 DFP 在 Wolfe 线搜索下有同样的结论，图 8.9(b) 显示它确实可能很慢。

对一般非凸目标，没有类似的定理：已有构造性例子说明，即使线搜索满足 Wolfe 条件，BFGS 也可能不收敛到驻点。实践中 BFGS 常常工作良好，但这不是定理所保证的。

局部收敛的刻画：Dennis–Moré 条件 全局收敛说的是终将到达，还要看到达的速度。称 $\boldsymbol{x}^{(t)} \to \boldsymbol{x}^\star$ 是**超线性收敛**（superlinear convergence），如果

$$\lim_{t\to\infty} \frac{\|\boldsymbol{x}^{(t+1)} - \boldsymbol{x}^\star\|_2}{\|\boldsymbol{x}^{(t)} - \boldsymbol{x}^\star\|_2} = 0. \tag{8.33}$$

Newton 法靠的是矩阵趋于 Hessian。拟牛顿矩阵一般并不趋于 Hessian，超线性收敛却仍然可能发生。下面的定理说明，真正需要的只是沿步方向准确。

定理 8.7 Dennis–Moré 特征 设 f 二阶连续可微，$\boldsymbol{x}^{(t)} \to \boldsymbol{x}^\star$，$\boldsymbol{x}^\star$ 是驻点，$\boldsymbol{H}^\star = \nabla^2 f(\boldsymbol{x}^\star)$ 正定。设对充分大的 t，迭代取单位步长且方向 $\boldsymbol{d}^{(t)} \neq \boldsymbol{0}$ 由 $\boldsymbol{B}^{(t)}\boldsymbol{d}^{(t)} = -\boldsymbol{g}^{(t)}$ 确定。则序列超线性收敛，当且仅当

$$\lim_{t\to\infty} \frac{\|(\boldsymbol{B}^{(t)} - \boldsymbol{H}^\star)\boldsymbol{d}^{(t)}\|_2}{\|\boldsymbol{d}^{(t)}\|_2} = 0. \tag{8.34}$$

证明 省略上标，把误差写成 $\boldsymbol{e} = \boldsymbol{x} - \boldsymbol{x}^\star$、$\boldsymbol{e}^+ = \boldsymbol{x}^+ - \boldsymbol{x}^\star$。与式 (8.5) 一样，梯度差等于平均 Hessian 乘 $\boldsymbol{d}$。代入 $\boldsymbol{g} = -\boldsymbol{B}\boldsymbol{d}$，得到关键等式

$$\boldsymbol{g}^+ = (\bar{\boldsymbol{H}} - \boldsymbol{H}^\star)\boldsymbol{d} + (\boldsymbol{H}^\star - \boldsymbol{B})\boldsymbol{d}.$$

因为 $\boldsymbol{x}^{(t)} \to \boldsymbol{x}^\star$ 且 Hessian 连续，所以 $\bar{\boldsymbol{H}} \to \boldsymbol{H}^\star$，第一项是 $o(\|\boldsymbol{d}\|_2)$。

充分性：设式 (8.34) 成立，则 $\|\boldsymbol{g}^+\|_2 = o(\|\boldsymbol{d}\|_2)$。在 $\boldsymbol{x}^\star$ 附近，$\nabla^2 f$ 的最小特征值不小于某个 $\mu_\star > 0$，所以

$$\|\boldsymbol{g}^+\|_2 \geq \mu_\star \|\boldsymbol{e}^+\|_2.$$

再由三角不等式，$\|\boldsymbol{d}\|_2$ 不超过两个误差的范数之和，于是

$$\|\boldsymbol{e}^+\|_2 \leq o(1)\big(\|\boldsymbol{e}\|_2 + \|\boldsymbol{e}^+\|_2\big).$$

移项即得 $\|\boldsymbol{e}^+\|_2 = o(\|\boldsymbol{e}\|_2)$。

必要性：设序列超线性收敛。由三角不等式，$\|\boldsymbol{d}\|_2$ 不小于 $\|\boldsymbol{e}\|_2 - \|\boldsymbol{e}^+\|_2$，而 $\|\boldsymbol{e}^+\|_2 = o(\|\boldsymbol{e}\|_2)$，于是 $\|\boldsymbol{e}\|_2 = O(\|\boldsymbol{d}\|_2)$。

∇f 在 $\boldsymbol{x}^\star$ 处为零且连续可微，所以 $\|\boldsymbol{g}^+\|_2$ 是 $\|\boldsymbol{e}^+\|_2$ 的同阶小量，于是

$$\|\boldsymbol{g}^+\|_2 = o(\|\boldsymbol{e}\|_2) = o(\|\boldsymbol{d}\|_2).$$

由关键等式解出第二项，并用 $\bar{\boldsymbol{H}} \to \boldsymbol{H}^\star$，得到式 (8.34)。 ■

式 (8.34) 称为Dennis–Moré 条件（Dennis–Moré condition）。它只比较矩阵在搜索方向上的作用，所以拟牛顿矩阵不必收敛到 Hessian。图 8.16(b) 印证了这一点：迭代结束时矩阵整体的误差约为 3%，沿步方向的误差约为 0.08%。

定理假设步长最终是 1。满足式 (8.34)且 $c_1 < 1/2$ 时，Wolfe 线搜索最终确实接受单位步长，证明可查阅[3]。这也是线搜索要优先试 $\alpha = 1$ 的理由：如果不试，或者试了又不接受，上面的超线性机制就用不上。

[3] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

BFGS 的超线性收敛 完整记忆的 BFGS 确实满足 Dennis–Moré 条件，但需要更强的正则性。若 $\boldsymbol{x}^{(t)} \to \boldsymbol{x}^\star$，$\boldsymbol{H}^\star$ 正定，$\nabla^2 f$ 在 $\boldsymbol{x}^\star$ 附近 Lipschitz 连续，且 $\sum_t \|\boldsymbol{x}^{(t)} - \boldsymbol{x}^\star\|_2 < \infty$，又有单位步长优先试探的线搜索，则 BFGS 超线性收敛。

证明要沿用定理 8.6的势函数并在 $\boldsymbol{H}^\star$ 定义的坐标下估计，篇幅较长，读者可查阅[4]。求和条件要求误差足够快地衰减，在定理 8.6的强凸条件下可以进一步证明它成立。Lipschitz 条件的作用是控制 $\bar{\boldsymbol{H}}^{(t)}$ 与 $\boldsymbol{H}^\star$ 之差，使测量误差可以累加。

[4] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

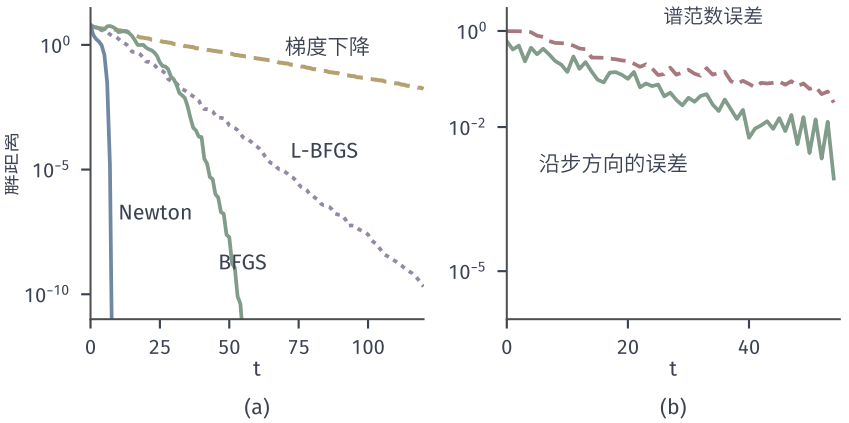


图 8.16 不同方法的局部速度，目标是 50 维的旋转 $\ln\cosh$ 函数（c_i 在 $[0.1, 100]$ 上对数等距，$\boldsymbol{x}^\star = \boldsymbol{0}$），强 Wolfe 线搜索。(a) 解距离随迭代的变化：梯度下降（黄虚线）线性且慢，$r = 5$ 的 L-BFGS（紫点线）线性，BFGS（绿）后期斜率变陡，Newton 法（蓝）最快。(b)BFGS 的矩阵相对误差：红虚线是 $\|\boldsymbol{B}^{(t)} - \boldsymbol{H}^\star\|_2 / \|\boldsymbol{H}^\star\|_2$，绿线是 Dennis–Moré 比值 $\|(\boldsymbol{B}^{(t)} - \boldsymbol{H}^\star)\boldsymbol{s}^{(t)}\|_2 / (\|\boldsymbol{H}^\star\|_2 \|\boldsymbol{s}^{(t)}\|_2)$。

SR1 的局部结论 SR1 的结论需要不同的条件，第 8.3节的定理只覆盖二次目标。对一般目标，已有的结果大致是：在 $\boldsymbol{H}^\star$ 正定、分母保持远离零、步方向具有一致线性无关性质时，$\boldsymbol{B}^{(t)}$ 本身收敛到 Hessian，配合信赖域可得到 $n+1$ 步意义下的超线性收敛。这些条件比 BFGS 的条件更难事先验证，也不能换成 Wolfe 线搜索下的方向分析；相应证明见[5]。

[5] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

L-BFGS 只保证线性收敛 完整 BFGS 的超线性结论不能自动移给固定记忆的 L-BFGS。超线性机制要求矩阵逐渐掌握沿步方向的曲率，而每轮重新从 $\gamma \boldsymbol{I}$ 开始、只用 r 对向量的矩阵，无法累积足够的信息。下面的定理给出固定记忆下能证明的保证。

定理 8.8 L-BFGS 的线性收敛 设 f 满足本节的基本假设，$t \ge 1$ 时 $\gamma^{(t)}$ 由式 (8.29)给出，$t=0$ 时取负梯度方向，记忆长度为 r，步长满足 Wolfe 条件。令 $T_{\mathrm{c}} = (n+r)L$，$\delta = (\mu/T_{\mathrm{c}})^{n+r}$。则

$$f(\boldsymbol{x}^{(t+1)}) - f^\star \le \Big(1 - \frac{2\mu c_1(1-c_2)\delta^2}{L}\Big)\big(f(\boldsymbol{x}^{(t)}) - f^\star\big). \tag{8.35}$$

证明 设 $\boldsymbol{B}_{[j]} = \boldsymbol{W}_{[j]}^{-1}$，它们由 $\boldsymbol{B}_{[t-r]} = (1/\gamma^{(t)})\boldsymbol{I}$ 出发，按 BFGS 的直接形式更新 r 次。第一步，由定理 8.6证明中的尺度估计，$1/\gamma^{(t)} \in [\mu, L]$。

第二步，约束迹。式 (8.15)的修正中，减去的一项迹非负，加上的一项迹不超过 L，于是

$$\operatorname{tr}\boldsymbol{B}_{[t]} \le \frac{n}{\gamma^{(t)}} + rL \le (n+r)L = T_{\mathrm{c}}.$$

所以每个 $\boldsymbol{B}_{[j]}$ 的最大特征值不超过 T_{c}。

第三步，约束行列式。由行列式公式和第一步，每次更新满足

$$\frac{\det \boldsymbol{B}_{[j+1]}}{\det \boldsymbol{B}_{[j]}} = \frac{\langle \boldsymbol{s}, \boldsymbol{y}\rangle}{\boldsymbol{s}^{\top}\boldsymbol{B}_{[j]}\boldsymbol{s}} \ge \frac{\mu\|\boldsymbol{s}\|_2^2}{T_{\mathrm{c}}\|\boldsymbol{s}\|_2^2} = \frac{\mu}{T_{\mathrm{c}}}.$$

连乘至多 r 次（窗口未满时次数更少，因 $\mu/T_{\mathrm{c}} \le 1$，下界不变），并用 $\det \boldsymbol{B}_{[t-r]} \ge \mu^n$，得到

$$\det \boldsymbol{B}^{(t)} \ge \mu^n \Big(\frac{\mu}{T_{\mathrm{c}}}\Big)^r.$$

第四步，约束方向角。最小特征值至少是行列式除以另外 $n-1$ 个特征值的上界，所以 $\boldsymbol{B}^{(t)}$ 的条件数不超过

$$\frac{T_{\mathrm{c}}^n}{\det \boldsymbol{B}^{(t)}} \le \Big(\frac{T_{\mathrm{c}}}{\mu}\Big)^{n+r} = \frac{1}{\delta}.$$

由 $\boldsymbol{d} = -\boldsymbol{W}\boldsymbol{g}$，方向角满足

$$\cos\theta^{(t)} = \frac{\boldsymbol{g}^{\top}\boldsymbol{W}\boldsymbol{g}}{\|\boldsymbol{g}\|_2\|\boldsymbol{W}\boldsymbol{g}\|_2} \ge \frac{\lambda_{\min}(\boldsymbol{W})}{\lambda_{\max}(\boldsymbol{W})} \ge \delta.$$

第五步，代入引理 8.5，并用第 1章的 $\|\boldsymbol{g}\|_2^2 \ge 2\mu(f - f^\star)$，即得式 (8.35)。 ■

定理的常数 δ 随 $n+r$ 指数变小，几乎没有定量价值。它的意义在于定性：固定记忆时，矩阵的条件数有界，因而线性收敛，且这个结论不依赖

超线性的机制。图 8.16(a) 中 L-BFGS 的直线正是线性收敛的样子，实际的速度远比定理的常数好。

各方法的保证 下表汇总本节的结论，列出的是使结论成立的条件，并非全部的可行条件。

方法	全局	局部
BFGS	强凸＋ Wolfe：收敛（已证）	Hessian Lipschitz、误差可和：超线性
DFP	本章的势函数论证不适用	不作结论
SR1	二次目标：至多 $n+1$ 步（已证）	分母与步方向条件＋信赖域：$n+1$ 步意义下超线性
L-BFGS	强凸＋ Wolfe：线性收敛（已证）	不保证超线性

表 8.5 拟牛顿方法的收敛保证汇总。

计算成本 比较成本要固定相同的精度，并把各项都算上。下表列出每一步除梯度外的开销，n 是变量维数，r 是记忆长度，线搜索的函数和梯度计算次数另算。

方法	存储	方向与更新的乘法次数
梯度下降	n	n
L-BFGS	$2rn$	$(4r+1)n$
BFGS、DFP、SR1	$n^2/2$	约 $4n^2$
Newton 法	$n^2/2$	约 $n^3/3$，另加形成 Hessian

表 8.6 每步除梯度以外的存储与运算，Newton 法按 Cholesky 分解计。

单步开销低的方法不一定总开销低，要乘上迭代数才能比较。图 8.16的目标取 $n=50$，达到解距离 10^{-8} 需要的迭代数和方向运算量如表 8.7所示。

方法	迭代数	每步方向运算	方向运算合计
梯度下降	458	50	2.3×10^4
L-BFGS（$r=5$）	104	1050	1.1×10^5
BFGS	51	1.0×10^4	5.1×10^5
Newton 法	8	4.2×10^4	3.3×10^5

表 8.7 图 8.16的目标（$n=50$）上达到解距离 10^{-8} 的迭代数与方向运算量，不含梯度和 Hessian 的计算。

8.1 割线条件
8.2 DFP 与 BFGS
8.3 SR1
8.4 L-BFGS
8.5 收敛与计算成本
8.6 本章小结

这张表不能单独读。这个目标上一次梯度要做两次 50×50 的矩阵乘法，约 5000 次运算，所以梯度下降实际花在梯度上的开销约为 2.3×10^6，远超方向运算本身。Newton 法的 Hessian 开销未计入；在 $n=50$ 时分解很便宜，n 增大后三次方项才成为主要矛盾。比较的结论要在实际的 n、梯度和 Hessian 成本下重新算。

实际选择大致如下：n 不大、梯度贵、要高精度时用完整 BFGS；n 很大时用 L-BFGS，代价是只有线性速度的保证；需要负曲率信息时用 SR1 配信赖域。

8.6 本章小结

本章开头的问题是：Hessian 算不起、存不下时，能否从迭代本身得到曲率信息。答案是相邻两点的梯度差。式 (8.5)说明它是平均 Hessian 作用在位移上的结果，由此得到割线条件。这个条件在 $n=1$ 时确定了曲率，$n>1$ 时还缺 $n(n-1)/2$ 个方程，所以需要补充对称、低秩和曲率的要求。

不同的补充要求产生了不同的方法。DFP 和 BFGS 各用两个秩一项，分别在矩阵和逆矩阵上度量改动。两者都在曲率条件 $\langle \boldsymbol{s},\boldsymbol{y}\rangle>0$ 下保持正定，Wolfe 线搜索使这个条件对任意光滑目标成立，跳过和阻尼是线搜索之外的备用办法。

SR1 只用一个秩一项，由割线条件唯一确定。它在二次目标上有更强的遗传性质，能记录负曲率，但分母可能近零，矩阵也可能不定，所以需要跳过规则，且方向分析不能照搬，要交给有界的模型处理。

L-BFGS 用双循环递推在不保存矩阵的情况下计算 $\boldsymbol{W}^{(t)}\boldsymbol{g}^{(t)}$，把存储从 $n^2/2$ 降到 $2rn$。记忆长度决定了方向的质量和每步的计算量，初始缩放决定了单位步长是否合适。

方法	新增信息	保持的性质	单步主要开销
BFGS	秩二修正	曲率条件下正定	$O(n^2)$
DFP	秩二修正	曲率条件下正定	$O(n^2)$
SR1	秩一修正	可表示负曲率	$O(n^2)$
L-BFGS	最近 r 对	曲率条件下正定	$O(rn)$

表 8.8 本章四种拟牛顿方法的比较。

收敛结论要分开看。BFGS 在强凸目标和 Wolfe 线搜索下全局收敛，在更强的正则性下超线性收敛，后者由 Dennis–Moré 条件刻画，它只要求沿步方向准确。L-BFGS 在强凸目标上线性收敛，完整记忆的超线性结论不能自动移给它。一般非凸目标上，这些保证都不成立，SR1 在一般目标上的局部结论也有额外条件。

拟牛顿矩阵的好坏，最终还要看模型在多大范围内可信。线搜索只沿一个方向试探，不定模型又没有极小点；第 9章研究的信赖域，把候选步和接受判断放在一起处理，并且既可以用精确 Hessian，也可以用本章的拟牛顿矩阵。

9.1 信赖域模型
9.2 子问题的求解
9.3 步的接受与半径更新
9.4 收敛与计算成本
9.5 本章小结

第 9 章

信赖域

站在一个点上，手里有目标的梯度和曲率，可以写出一个二次模型，模型的最小点似乎就是下一步该去的地方。可是模型只是在当前点附近展开得到的，走远了它就可能完全失真；曲率不正定时，模型甚至没有最小点。第 5章的线搜索先定方向、再定步长，方向一旦定错，步长再怎么调也救不回来。

本章换一个顺序：先问“模型能信多远”，在这个范围内求模型的最小点，方向和长度一起决定，再用真实目标检验模型预测得准不准，据此调整下一轮的范围。这样得到的方法叫**信赖域**（trust region）方法。

全章用同一个二维目标把这件事算到底。先写出子问题，看清它的解长什么样；再比较三种便宜的近似求解办法；然后组织完整的迭代，看一步被拒绝时发生什么；最后讨论这套做法能保证什么、不能保证什么，以及它的计算代价。

9.1 信赖域模型

既然局部模型只在一定范围内可靠，怎样把“只在这个范围内相信它”写成一个可以计算的问题？

贯穿全章的例子　我们用下面这个二维目标：

$$f(\boldsymbol{x}) = \frac{1}{4}x_1^4 - \frac{1}{2}x_1^2 + x_1 + \frac{3}{2}x_2^2 + x_2. \tag{9.1}$$

它的梯度和 Hessian 可以直接写出：

$$\nabla f(\boldsymbol{x}) = \begin{bmatrix} x_1^3 - x_1 + 1 \\ 3x_2 + 1 \end{bmatrix}, \qquad \nabla^2 f(\boldsymbol{x}) = \begin{bmatrix} 3x_1^2 - 1 & 0 \\ 0 & 3 \end{bmatrix}. \tag{9.2}$$

令梯度为零，第二个分量给出 $x_2 = -1/3$，第一个分量是三次方程 $x_1^3 - x_1 + 1 = 0$，它只有一个实根 $x_1 \approx -1.3247$。这个驻点处 Hessian 正定，f 又随 $\|\boldsymbol{x}\|_2 \to \infty$ 趋于正无穷，所以它就是全局最小点：

$$\boldsymbol{x}^\star \approx (-1.3247, -0.3333)^\top, \qquad f^\star \approx -1.5989.$$

全章反复用到两个点。一个是 $\boldsymbol{a} = (2, 2)^\top$，这里 Hessian 正定，数据是

$$f(\boldsymbol{a}) = 12, \qquad \boldsymbol{g} = \begin{bmatrix} 7 \\ 7 \end{bmatrix}, \qquad \boldsymbol{B} = \begin{bmatrix} 11 & 0 \\ 0 & 3 \end{bmatrix}. \tag{9.3}$$

另一个是原点，这里 Hessian 不定，数据是

$$f(\boldsymbol{0}) = 0, \qquad \boldsymbol{g} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \qquad \boldsymbol{B} = \begin{bmatrix} -1 & 0 \\ 0 & 3 \end{bmatrix}. \tag{9.4}$$

模型能信多远 在当前点 $\boldsymbol{x}^{(t)}$ 展开到二阶，用位移 $\boldsymbol{p}$ 作自变量，就得到**二次模型**（quadratic model）：

$$m^{(t)}(\boldsymbol{p}) = f(\boldsymbol{x}^{(t)}) + \langle \boldsymbol{g}^{(t)}, \boldsymbol{p} \rangle + \frac{1}{2} \boldsymbol{p}^\top \boldsymbol{B}^{(t)} \boldsymbol{p}. \tag{9.5}$$

其中 $\boldsymbol{g}^{(t)} = \nabla f(\boldsymbol{x}^{(t)})$，$\boldsymbol{B}^{(t)}$ 是对称矩阵，可以取 Hessian $\boldsymbol{H}^{(t)}$，也可以取第 8章由梯度差构造的近似。本节取 $\boldsymbol{B}^{(t)} = \boldsymbol{H}^{(t)}$。

模型与目标差多少？例中 x_2 部分本来就是二次的，没有误差；x_1 部分由四次多项式的展开直接得到，当 $\boldsymbol{B}$ 取 Hessian 时

$$f(\boldsymbol{x} + \boldsymbol{p}) - m(\boldsymbol{p}) = x_1 p_1^3 + \frac{1}{4} p_1^4. \tag{9.6}$$

误差随 $|p_1|$ 的增大而迅速增大。$|p_1|$ 很小时，高阶项微不足道；$|p_1|$ 到了 2，在原点误差就是 4，已经超过这里函数值变化的量级。图 9.1沿 x_1 方向画出了这件事，浅蓝带表示模型大致可信的范围。

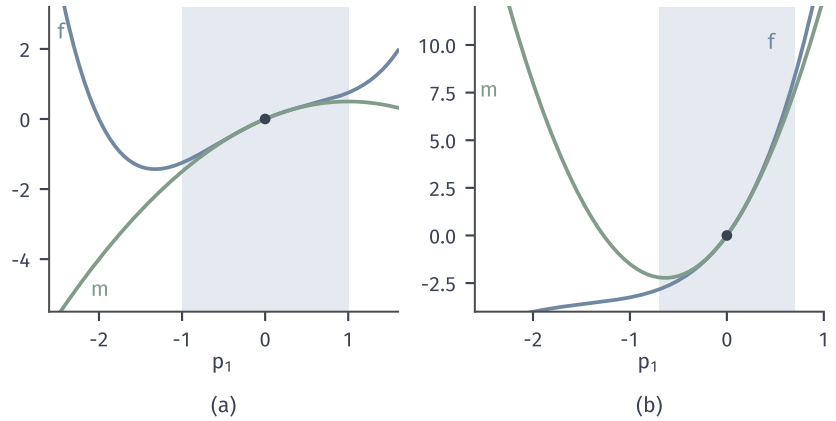


图 9.1 目标 (9.1)的 x_1 部分（蓝）与二次模型（绿）沿 p_1 的比较，黑点是展开点，浅蓝带是两者大致重合的范围。(a) 在 $x_1 = 0$ 展开，曲率为负，模型向左无限下降，而目标很快转头向上。(b) 在 $x_1 = 2$ 展开，曲率为正，模型有最小点，但左侧的目标比模型低得多。

图 9.2在平面上比较同一件事。在点 $\boldsymbol{a}$ 附近，两组等高线几乎一样；离开圆盘之后，目标的等高线向左拉伸，模型仍是一组椭圆。

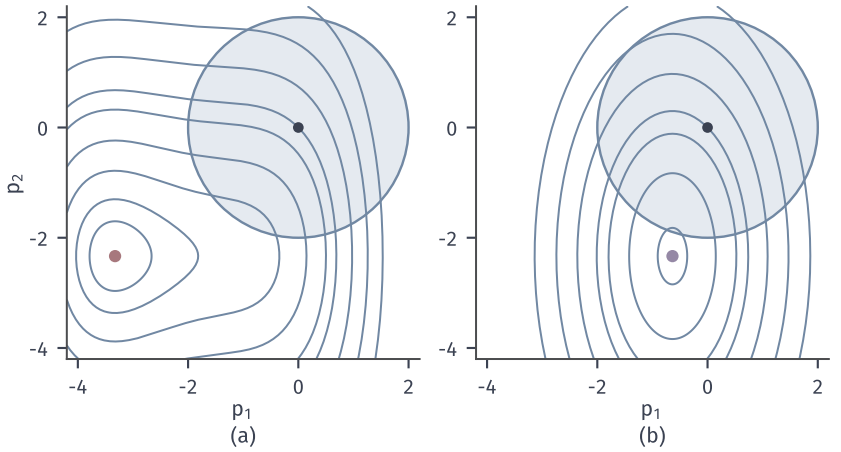


图 9.2 以 $\boldsymbol{a} = (2, 2)^{\mathsf{T}}$ 为原点的位移坐标下的等高线（蓝）。(a) 真实目标，红点是最小点。(b) 二次模型，紫点是模型的最小点。浅蓝圆盘半径为 2，圆盘内两图相近，圆盘外差别明显。

子问题 既然模型只在附近可靠，就只在附近找它的最小点。给定半径 $\Delta^{(t)} > 0$，定义**信赖域子问题**（trust-region subproblem）：

$$\min_{\boldsymbol{p} \in \mathbb{R}^n} m^{(t)}(\boldsymbol{p}) \qquad \text{满足} \quad \|\boldsymbol{p}\|_2 \le \Delta^{(t)}. \tag{9.7}$$

半径 $\Delta^{(t)}$ 约束的是这一轮的位移，原问题仍然是无约束的。下一轮换一个点、换一个半径，约束也跟着换。

半径的含义可以用一张手绘地图来理解。地图是在当前位置附近勘测的（对应二次模型），周围画得准，远处多半是推测。你决定只按地图走到某个距离为止（对应半径），走到后核对实地与地图是否相符，相符就下次敢走远些，不符就走近些（对应后面的半径更新）。这个类比有一处不贴切：半径并不是模型真实误差的边界，它只是算法根据最近的核对结果作出的估计，可能偏大，也可能偏小。

曲率不正定时 第 7章的 Newton 法要解 $\boldsymbol{B}\boldsymbol{d} = -\boldsymbol{g}$。原点的数据 (9.4)上这个方程仍可解，解是

$$\boldsymbol{d}^{\mathrm{N}} = -\boldsymbol{B}^{-1}\boldsymbol{g} = \begin{bmatrix} 1 \\ -1/3 \end{bmatrix}.$$

它与梯度的内积决定这个方向是上坡还是下坡：

$$\langle \boldsymbol{g}, \boldsymbol{d}^{\mathrm{N}} \rangle = 1 - \frac{1}{3} = \frac{2}{3} > 0.$$

内积为正，这个方向是上坡方向。$\boldsymbol{d}^{\mathrm{N}}$ 只是模型的驻点，模型在这里是个鞍面。沿 $\boldsymbol{d}^{\mathrm{N}}$ 作线搜索不会有任何下降的步长，所以线搜索框架不得不先修改 $\boldsymbol{B}$，使它正定。

信赖域子问题没有这个麻烦。闭球是紧集，m 连续，所以无论 $\boldsymbol{B}$ 是否正定，最小点都存在。例中模型沿 p_1 轴是 $p_1 - p_1^2/2$，向左无限下降，无约束时没有最小点；加上半径之后，解就落在球的边界上。图 9.3画出了 $\Delta = 2$ 的情形：$\boldsymbol{B}$ 无需修改，负曲率反而被利用，它把解推向了边界。

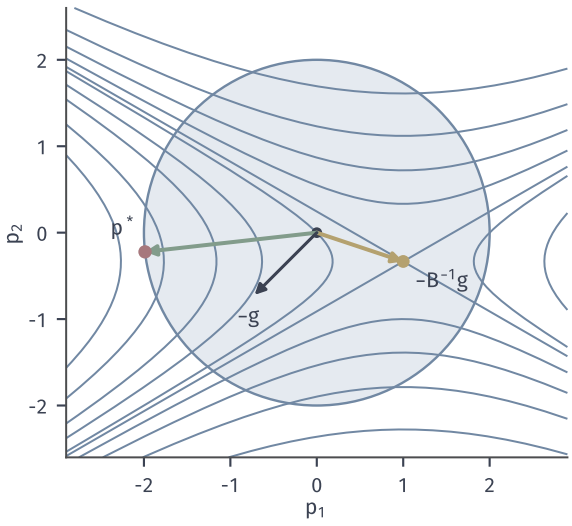


图 9.3 原点处的二次模型，蓝线是等高线，浅蓝圆盘半径 $\Delta = 2$。黄色箭头指向模型的驻点 $-\boldsymbol{B}^{-1}\boldsymbol{g}$，黑色箭头是负梯度方向，红点是子问题的全局解 $\boldsymbol{p}^{\star}$，绿色箭头指向它。黄色方向是上坡方向，而子问题的解利用负曲率走到了圆盘左侧边界。

与线搜索的对照 第 5章的线搜索分两步：先选定下降方向 $\boldsymbol{d}^{(t)}$，再沿这条射线选步长 $\alpha^{(t)}$。信赖域把顺序倒过来：先选定半径，再同时决定方向和长度。半径变了，步的方向也跟着变。

在点 $\boldsymbol{a}$，图 9.4画出了两者的差别。线搜索的候选点都在一条射线上；信赖域的解随半径变化走出一条曲线，半径小时贴近负梯度方向，半径大时转向 Newton 点。半径的调整因此比步长的调整多一层作用，它还在改变方向。

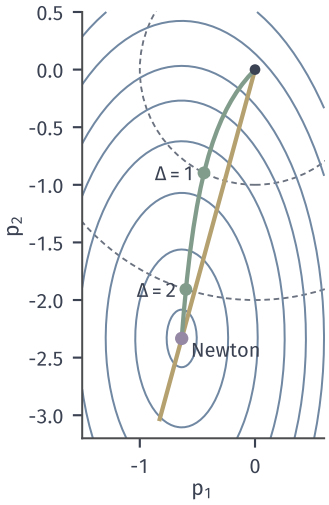


图 9.4 点 $\boldsymbol{a}$ 处的二次模型等高线（蓝）。黄线是沿 Newton 方向的射线，线搜索只在这条线上选点。绿线是子问题的全局解随 Δ 变化的轨迹，绿点是 $\Delta = 1$ 和 $\Delta = 2$ 时的解，虚线圆是对应的边界，紫点是 Newton 点。

表 9.1把两种做法并列。

	线搜索	信赖域
先固定的量	方向 $\boldsymbol{d}^{(t)}$	半径 $\Delta^{(t)}$
后决定的量	步长 $\alpha^{(t)}$	位移 $\boldsymbol{p}^{(t)}$（方向和长度）
$\boldsymbol{B}$ 的要求	需要给出下降方向	对称即可
一次试探失败	缩短步长，方向不变	缩小半径，方向可变

表 9.1 线搜索与信赖域的分工对照。

子问题的全局解 子问题虽然非凸，它的全局解却有干净的刻画。下面的定理说明，解满足一个被平移过的线性方程，平移量 λ 恰好使矩阵半正定。

定理 9.1　子问题的全局解　设 $\boldsymbol{B}$ 对称，$\Delta>0$，m 如式 (9.5)（省略上标 (t)）。点 $\boldsymbol{p}^\star$ 是子问题 (9.7)的全局解，当且仅当 $\|\boldsymbol{p}^\star\|_2\le\Delta$，并且存在 $\lambda\ge 0$，使得

$$(\boldsymbol{B}+\lambda\boldsymbol{I})\boldsymbol{p}^\star=-\boldsymbol{g},\qquad \lambda(\Delta-\|\boldsymbol{p}^\star\|_2)=0,\qquad \boldsymbol{B}+\lambda\boldsymbol{I}\succeq\boldsymbol{0}. \tag{9.8}$$

证明　先证充分性。令

$$\hat m(\boldsymbol{p})=m(\boldsymbol{p})+\frac{\lambda}{2}\|\boldsymbol{p}\|_2^2.$$

它的 Hessian 是 $\boldsymbol{B}+\lambda\boldsymbol{I}\succeq\boldsymbol{0}$，所以是凸函数；式 (9.8)的第一式说明 $\nabla\hat m(\boldsymbol{p}^\star)=\boldsymbol{0}$，因此 $\boldsymbol{p}^\star$ 是 $\hat m$ 的全局最小点。对任意 $\|\boldsymbol{p}\|_2\le\Delta$，把 $\hat m(\boldsymbol{p})\ge\hat m(\boldsymbol{p}^\star)$ 展开，得到

$$m(\boldsymbol{p})\ge m(\boldsymbol{p}^\star)+\frac{\lambda}{2}\bigl(\|\boldsymbol{p}^\star\|_2^2-\|\boldsymbol{p}\|_2^2\bigr).$$

若 $\lambda=0$，右端就是 $m(\boldsymbol{p}^\star)$。若 $\lambda>0$，第二式给出 $\|\boldsymbol{p}^\star\|_2=\Delta$，括号非负。两种情形都有 $m(\boldsymbol{p})\ge m(\boldsymbol{p}^\star)$。

再证必要性。若 $\|\boldsymbol{p}^\star\|_2<\Delta$，$\boldsymbol{p}^\star$ 是二次函数的内部局部极小点，于是梯度 $\boldsymbol{B}\boldsymbol{p}^\star+\boldsymbol{g}=\boldsymbol{0}$，Hessian $\boldsymbol{B}\succeq\boldsymbol{0}$，取 $\lambda=0$ 即可。

下设 $\|\boldsymbol{p}^\star\|_2=\Delta$，分三步。第一步找乘子。任取与 $\boldsymbol{p}^\star$ 正交的单位向量 $\boldsymbol{v}$，下面的曲线落在球面上：

$$\boldsymbol{q}(\theta)=\cos\theta\,\boldsymbol{p}^\star+\Delta\sin\theta\,\boldsymbol{v}.$$

$\theta=0$ 时函数 $m(\boldsymbol{q}(\theta))$ 最小，导数为零：

$$\Delta\,\langle\boldsymbol{B}\boldsymbol{p}^\star+\boldsymbol{g},\boldsymbol{v}\rangle=0.$$

所以 $\boldsymbol{B}\boldsymbol{p}^\star+\boldsymbol{g}$ 与所有切向量正交，它只能是 $\boldsymbol{p}^\star$ 的倍数，记为 $-\lambda\boldsymbol{p}^\star$，这就是第一式。

第二步证 $\lambda\ge0$。对 $s\in[0,1]$，点 $(1-s)\boldsymbol{p}^\star$ 可行，$m((1-s)\boldsymbol{p}^\star)$ 在 $s=0$ 的右导数不能为负：

$$-\langle\boldsymbol{B}\boldsymbol{p}^\star+\boldsymbol{g},\boldsymbol{p}^\star\rangle=\lambda\Delta^2\ge0.$$

第三步证半正定。$\hat m$ 是二次函数且在 $\boldsymbol{p}^\star$ 处梯度为零，所以

$$\hat m(\boldsymbol{p})-\hat m(\boldsymbol{p}^\star)=\frac12(\boldsymbol{p}-\boldsymbol{p}^\star)^{\top}(\boldsymbol{B}+\lambda\boldsymbol{I})(\boldsymbol{p}-\boldsymbol{p}^\star).$$

当 $\|\boldsymbol{p}\|_2 = \Delta$ 时，$\hat{m}$ 与 m 的差相同，而 $m(\boldsymbol{p}) \geq m(\boldsymbol{p}^\star)$，于是

$$(\boldsymbol{p} - \boldsymbol{p}^\star)^{\top}(\boldsymbol{B} + \lambda \boldsymbol{I})(\boldsymbol{p} - \boldsymbol{p}^\star) \geq 0.$$

任取满足 $\langle \boldsymbol{w}, \boldsymbol{p}^\star \rangle \neq 0$ 的 $\boldsymbol{w}$，令

$$\boldsymbol{p} = \boldsymbol{p}^\star - 2\frac{\langle \boldsymbol{w}, \boldsymbol{p}^\star \rangle}{\langle \boldsymbol{w}, \boldsymbol{w} \rangle}\boldsymbol{w}.$$

这是 $\boldsymbol{p}^\star$ 关于 $\boldsymbol{w}$ 的法平面的反射，长度仍为 Δ，而 $\boldsymbol{p} - \boldsymbol{p}^\star$ 与 $\boldsymbol{w}$ 平行，所以 $\boldsymbol{w}^{\top}(\boldsymbol{B} + \lambda \boldsymbol{I})\boldsymbol{w} \geq 0$。满足 $\langle \boldsymbol{w}, \boldsymbol{p}^\star \rangle \neq 0$ 的 $\boldsymbol{w}$ 在 $\mathbb{R}^n$ 中稠密，由连续性，不等式对所有 $\boldsymbol{w}$ 成立。 ■

三个条件各有作用。第一式说明解是一个被“加了 λ”的 Newton 方程的解，λ 越大，方程越接近 $\lambda \boldsymbol{p} = -\boldsymbol{g}$，解越贴近负梯度方向。第二式说明半径不起作用时 $\lambda = 0$，解就是 Newton 点。第三式是全局性的来源：它要求 λ 至少抵消最负的特征值，只满足前两式的点可能只是局部解或驻点。

λ 的作用类似预算约束下的影子价格：半径限得越紧，λ 越大。这个类比只说明单调关系，λ 的单位与目标值的单位并不相同。

怎样求 λ　设 $\boldsymbol{B}$ 的特征值为 $\lambda_1 \leq \cdots \leq \lambda_n$，对应的单位正交特征向量为 $\boldsymbol{q}_1, \dots, \boldsymbol{q}_n$。当 $\lambda > \max\{0, -\lambda_1\}$ 时，式 (9.8)的第一式有唯一解 $\boldsymbol{p}(\lambda)$，它的长度满足

$$\|\boldsymbol{p}(\lambda)\|_2^2 = \sum_{i=1}^{n} \frac{\langle \boldsymbol{q}_i, \boldsymbol{g} \rangle^2}{(\lambda_i + \lambda)^2}. \tag{9.9}$$

每一项都随 λ 严格减小（只要系数不为零）。求解子问题于是化为一元方程 $\|\boldsymbol{p}(\lambda)\|_2 = \Delta$，称为**久期方程**（secular equation）。

点 $\boldsymbol{a}$ 的数据 (9.3)上，取 $\Delta = 2$，式 (9.9)成为

$$\|\boldsymbol{p}(\lambda)\|_2^2 = \frac{49}{(11 + \lambda)^2} + \frac{49}{(3 + \lambda)^2}.$$

$\lambda = 0$ 时长度约为 2.419，大于 Δ，Newton 点在球外，所以 $\lambda > 0$。再试几个值：

$$\|\boldsymbol{p}(0.5)\|_2 \approx 2.091, \qquad \|\boldsymbol{p}(0.7)\|_2 \approx 1.984, \qquad \|\boldsymbol{p}(0.67)\|_2 \approx 1.9995.$$

继续缩小区间，得到 $\lambda \approx 0.669$，相应的解是

$$\boldsymbol{p}^\star \approx (-0.600, -1.908)^{\top}.$$

实际计算不用谱分解，而是对几个试探的 λ 作 Cholesky 分解，用 Newton 迭代解 $1/\|\boldsymbol{p}(\lambda)\|_2 = 1/\Delta$；这个函数比长度本身更接近线性，几次迭代就够了。

图 9.5(a) 是这条曲线。原点的数据上（图 9.5(b)），$\boldsymbol{B}$ 有负特征值 -1，只能在 $\lambda > 1$ 的范围内找解。曲线在 $\lambda = 1$ 处趋于无穷，所以对任何半径都有交点，$\Delta = 2$ 时 $\lambda \approx 1.503$。

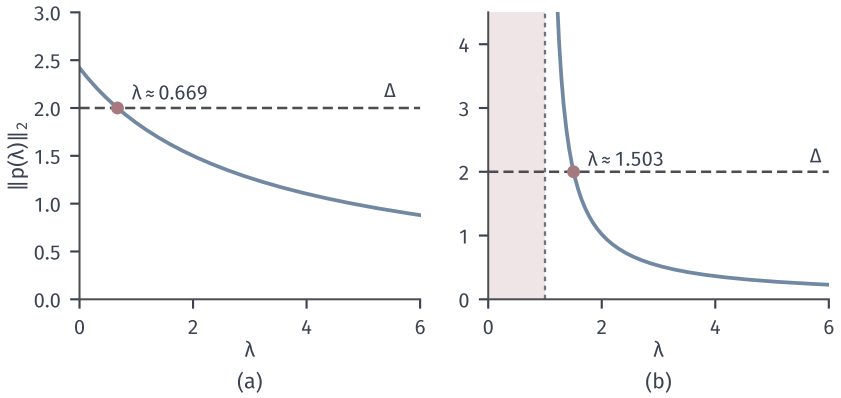


图 9.5 解的长度 $\|\boldsymbol{p}(\lambda)\|_2$（蓝）与半径 $\Delta = 2$（虚线）的交点（红）给出乘子。(a) 点 $\boldsymbol{a}$，$\boldsymbol{B}$ 正定，曲线从 Newton 步的长度开始下降。(b) 原点，$\boldsymbol{B}$ 的最小特征值为 -1，红色浅底的区域 $\lambda < 1$ 不满足 $\boldsymbol{B} + \lambda \boldsymbol{I} \succeq \boldsymbol{0}$。

困难情形 上面的论证依赖 $\langle \boldsymbol{q}_1, \boldsymbol{g} \rangle \neq 0$。如果梯度与最小特征值的特征空间正交，式 (9.9)中对应的项消失，曲线在 $\lambda = -\lambda_1$ 处不再趋于无穷，久期方程可能无解。这称为子问题的**困难情形**（hard case）。

看下面这组数据：

$$\boldsymbol{g} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \qquad \boldsymbol{B} = \begin{bmatrix} -1 & 0 \\ 0 & 3 \end{bmatrix}, \qquad \Delta = 1.$$

当 $\lambda > 1$ 时，第一式给出的解是

$$\boldsymbol{p}(\lambda) = \begin{bmatrix} 0 \\ -1/(\lambda + 3) \end{bmatrix},$$

长度小于 $1/4$，够不到边界。定理 9.1要求 $\lambda \geq 1$，所以只能取 $\lambda = 1$。此时 $\boldsymbol{B} + \boldsymbol{I} = \operatorname{diag}(0, 4)$ 奇异，方程的解不唯一：

$$\boldsymbol{p} = \begin{bmatrix} \tau \\ -1/4 \end{bmatrix}, \qquad \tau \in \mathbb{R}.$$

沿奇异方向补足长度，使 $\|\boldsymbol{p}\|_2 = 1$，得到两个全局解：

$$\tau = \pm\frac{\sqrt{15}}{4}, \qquad m(\boldsymbol{p}) - m(\boldsymbol{0}) = -\frac{5}{8}.$$

图 9.6比较了 g_1 很小与 $g_1 = 0$ 两种情形。$g_1 = 0.1$ 时交点贴近 $\lambda = 1$；g_1 恰好为零时，曲线在 $\lambda = 1$ 处停在 $1/4$，交点消失，解要靠特征向量补足。

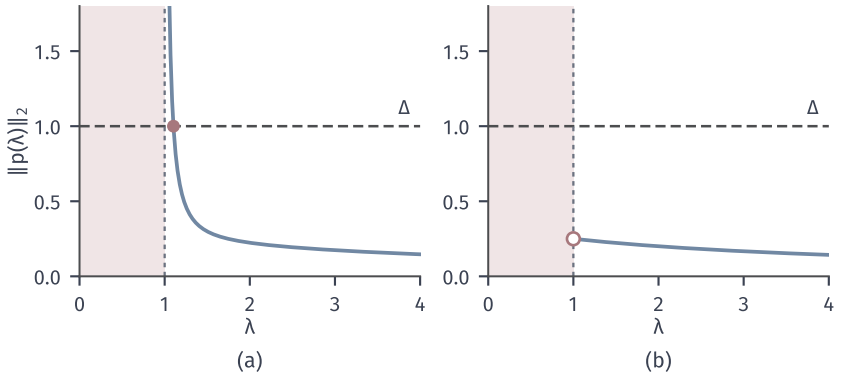


图 9.6 $\boldsymbol{B} = \mathrm{diag}(-1, 3)$，$\Delta = 1$（虚线）时的解长度（蓝）。(a) $\boldsymbol{g} = (0.1, 1)^{\mathsf{T}}$，曲线在 $\lambda = 1$ 处趋于无穷，有交点。(b) $\boldsymbol{g} = (0, 1)^{\mathsf{T}}$，曲线只到 $1/4$（空心点），与虚线不相交，这是困难情形。

三个不同的量 子问题的解、模型的下降、真实目标的下降是三件事，下面把它们分开。对候选步 $\boldsymbol{p}$，定义**预测下降**（predicted reduction）和**实际下降**（actual reduction）：

$$\mathrm{pred}(\boldsymbol{p}) = m(\boldsymbol{0}) - m(\boldsymbol{p}), \qquad \mathrm{ared}(\boldsymbol{p}) = f(\boldsymbol{x}) - f(\boldsymbol{x} + \boldsymbol{p}). \tag{9.10}$$

子问题的全局解使预测下降最大，却未必使实际下降最大。在原点取 $\Delta = 2$，全局解是 $\boldsymbol{p}^\star \approx (-1.988, -0.222)^{\mathsf{T}}$。由式 (9.6)，它的模型误差大约是 $\frac{1}{4}(1.988)^4 \approx 3.90$，于是

$$\mathrm{pred}(\boldsymbol{p}^\star) \approx 4.111, \qquad \mathrm{ared}(\boldsymbol{p}^\star) \approx 0.209.$$

再看同一个球内的另一个点 $\boldsymbol{p} = (-1.6, -1.2)^{\mathsf{T}}$。它的预测下降小得多，实际下降反而大一些：

$$\mathrm{pred}(\boldsymbol{p}) = 1.92, \qquad \mathrm{ared}(\boldsymbol{p}) \approx 0.282.$$

这个对比说明，模型下降的大小只是在模型的范围内才有意义。图 9.7画出全局解的两种下降随半径的变化：半径小时两条曲线重合，半径大时预测下降继续上升，实际下降掉头向下。预测和实际的差距正是调整半径的依据，后面第 9.3节用它们的比值组织迭代。

9.1 信赖域模型
9.2 子问题的求解
9.2.1 Cauchy 步
9.2.2 狗腿法
9.2.3 截断共轭梯度
9.3 步的接受与半径更新
9.4 收敛与计算成本
9.5 本章小结

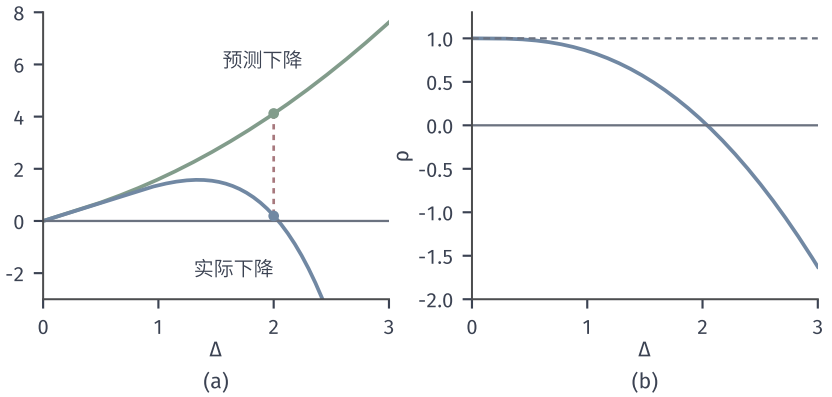


图 9.7 原点处子问题全局解随半径的变化。(a) 预测下降（绿）与实际下降（蓝），红色虚线标出 $\Delta = 2$ 处的差距。(b) 实际下降与预测下降之比 ρ（蓝），半径越大越偏离 1，在 Δ 约为 2 时降到零附近。

9.2 子问题的求解

第 9.1节的刻画需要分解 $\boldsymbol{B} + \lambda \boldsymbol{I}$ 好几次，每一轮外层迭代都这样做，代价可能比外层本身还高。接下来要弄清：能否用便宜得多的办法得到一个“够用”的步？

下面对同一个模型和同一个半径比较三种计算。它们是：只沿负梯度取步、把负梯度步与 Newton 步连起来、用共轭梯度迭代逐步逼近。主例取点 $\boldsymbol{a}$ 的数据 (9.3)，半径 $\Delta = 2$；Hessian 不定的情形用原点的数据 (9.4)。外层迭代真正需要的，不是子问题的精确解，而是模型下降达到一个规定的比例。这个比例由最简单的那种步来给出。

本节所有量都在同一轮外层迭代内，省略上标 (t)，写 $m, \boldsymbol{g}, \boldsymbol{B}, \Delta$。

9.2.1 Cauchy 步

沿负梯度最小化模型 最便宜的做法是只在负梯度这条射线上找模型的最小点。设 $\boldsymbol{g} \neq \boldsymbol{0}$，把点写成 $\boldsymbol{p} = -a\,\boldsymbol{g}/\|\boldsymbol{g}\|_2$，其中 $a \in [0, \Delta]$ 是走过的长度。令

$$\kappa = \frac{\boldsymbol{g}^{\top} \boldsymbol{B} \boldsymbol{g}}{\|\boldsymbol{g}\|_2^2},$$

它是模型沿负梯度方向的曲率。代入式 (9.5)，模型的变化量是一元二次函数

$$\psi(a) = m\Big(-a \frac{\boldsymbol{g}}{\|\boldsymbol{g}\|_2}\Big) - m(\boldsymbol{0}) = -a\|\boldsymbol{g}\|_2 + \frac{\kappa}{2} a^2. \tag{9.11}$$

在 $[0, \Delta]$ 上最小化 ψ，分两种情形。若 $\kappa \le 0$，ψ 严格递减，应当走到边界 $a = \Delta$。若 $\kappa > 0$，ψ 的顶点在 $a = \|\boldsymbol{g}\|_2/\kappa$，它在区间内就取顶点，否则

截断在边界。合起来就得到Cauchy 步（Cauchy step）的长度，步本身记为 $\boldsymbol{p}^{\mathrm{C}}$：

$$\boldsymbol{p}^{\mathrm{C}} = -a^{\mathrm{C}} \frac{\boldsymbol{g}}{\|\boldsymbol{g}\|_2}, \qquad a^{\mathrm{C}} = \begin{cases} \Delta, & \kappa \le 0, \\ \min\{\Delta,\ \|\boldsymbol{g}\|_2/\kappa\}, & \kappa > 0. \end{cases} \tag{9.12}$$

图 9.8画出三种情形。计算时只需要一次矩阵向量乘积 $\boldsymbol{B}\boldsymbol{g}$。

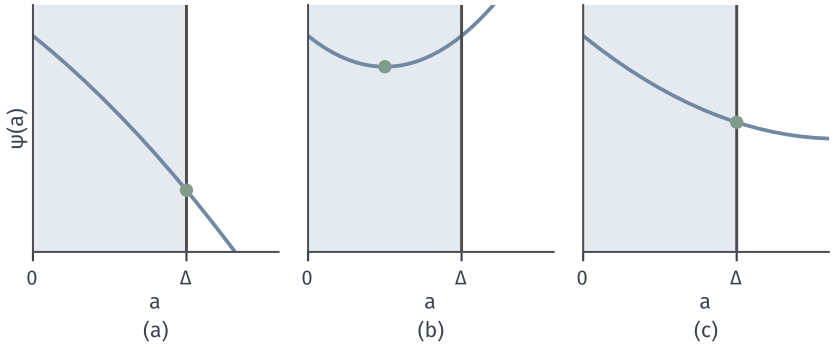


图 9.8　函数 $\psi(a)$（蓝）的三种情形，浅蓝带是可取的范围，深灰线是边界，绿点是 Cauchy 步的长度。(a) $\kappa \le 0$，走到边界。(b) $\kappa > 0$ 且顶点在区间内，取顶点。(c) $\kappa > 0$ 但顶点在区间外，截断在边界。

点 $\boldsymbol{a}$ 的数据上，$\boldsymbol{g}^{\top}\boldsymbol{B}\boldsymbol{g} = 49 \times 14 = 686$，$\|\boldsymbol{g}\|_2^2 = 98$，所以

$$\kappa = 7, \qquad \|\boldsymbol{g}\|_2 = 7\sqrt{2}, \qquad \frac{\|\boldsymbol{g}\|_2}{\kappa} = \sqrt{2}.$$

半径 $\Delta = 2$ 大于 $\sqrt{2}$，Cauchy 步取顶点：

$$\boldsymbol{p}^{\mathrm{C}} = -\sqrt{2} \cdot \frac{(7,7)^{\top}}{7\sqrt{2}} = \begin{bmatrix} -1 \\ -1 \end{bmatrix}, \qquad \mathrm{pred}(\boldsymbol{p}^{\mathrm{C}}) = 7\sqrt{2} \cdot \sqrt{2} - \frac{7}{2} \cdot 2 = 7.$$

半径若取 $\Delta = 1$，则截断在边界，$a^{\mathrm{C}} = 1$，预测下降为 $7\sqrt{2} - 3.5 \approx 6.40$。

Cauchy 步提供的模型下降　Cauchy 步便宜，它的价值却在于给出了一条有保证的下限。下面的引理说明，它的预测下降由梯度大小、半径和曲率上界控制。

引理 9.2　Cauchy 步的下降量　设 $\boldsymbol{g} \neq \boldsymbol{0}$，$\boldsymbol{B}$ 对称。Cauchy 步满足

$$\mathrm{pred}(\boldsymbol{p}^{\mathrm{C}}) \ge \frac{1}{2}\|\boldsymbol{g}\|_2 \min\left\{\Delta,\ \frac{\|\boldsymbol{g}\|_2}{\|\boldsymbol{B}\|_2}\right\}, \tag{9.13}$$

其中 $\boldsymbol{B} = \boldsymbol{0}$ 时第二项理解为 $+\infty$。

证明 由式 (9.11)，预测下降是

$$\operatorname{pred}(\boldsymbol{p}^{\mathrm{C}}) = a^{\mathrm{C}}\|\boldsymbol{g}\|_2 - \frac{\kappa}{2}(a^{\mathrm{C}})^2,$$

并且 $\kappa \le \|\boldsymbol{B}\|_2$。按三种情形估计。

若 $\kappa \le 0$，则 $a^{\mathrm{C}} = \Delta$，第二项非负，所以

$$\operatorname{pred}(\boldsymbol{p}^{\mathrm{C}}) \ge \Delta\|\boldsymbol{g}\|_2.$$

若 $\kappa > 0$ 且 $\|\boldsymbol{g}\|_2/\kappa \le \Delta$，则取顶点，所以

$$\operatorname{pred}(\boldsymbol{p}^{\mathrm{C}}) = \frac{\|\boldsymbol{g}\|_2^2}{2\kappa} \ge \frac{\|\boldsymbol{g}\|_2^2}{2\|\boldsymbol{B}\|_2}.$$

若 $\kappa > 0$ 且 $\|\boldsymbol{g}\|_2/\kappa > \Delta$，则 $a^{\mathrm{C}} = \Delta$，并且 $\kappa\Delta < \|\boldsymbol{g}\|_2$，所以

$$\operatorname{pred}(\boldsymbol{p}^{\mathrm{C}}) = \Delta\|\boldsymbol{g}\|_2 - \frac{\kappa\Delta}{2}\Delta \ge \frac{1}{2}\Delta\|\boldsymbol{g}\|_2.$$

三种情形都不小于式 (9.13)的右端。 ■

点 $\boldsymbol{a}$ 的数据上 $\|\boldsymbol{B}\|_2 = 11$，取 $\Delta = 2$，式 (9.13)的右端是

$$\frac{1}{2}\cdot 7\sqrt{2}\cdot \min\Big\{2,\ \frac{7\sqrt{2}}{11}\Big\} = \frac{49}{11} \approx 4.45,$$

确实不超过实际的预测下降 7。这个下限比实际值松，它的用处在于对所有模型一致成立。

这条下限只用到一阶信息和曲率的上界，$\boldsymbol{B}$ 可以不定。我们把它提升为对任意候选步的要求：若存在常数 $c_1 \in (0, 1]$，使得

$$\operatorname{pred}(\boldsymbol{p}) \ge c_1\|\boldsymbol{g}\|_2 \min\Big\{\Delta,\ \frac{\|\boldsymbol{g}\|_2}{\|\boldsymbol{B}\|_2}\Big\}, \tag{9.14}$$

就说 $\boldsymbol{p}$ 达到**充分模型下降**（sufficient model decrease）。第 9.4节会看到，一阶收敛只需要这一条；任何预测下降不低于 Cauchy 步的求解器，都自动满足它，$c_1 = 1/2$。

要分清这条保障和精确求解的差别。式 (9.14)只是一条下限，并不表示接近子问题的最优值。点 $\boldsymbol{a}$ 上 Cauchy 步的预测下降是 7，全局解是 10.115；原点上 $\Delta = 2$ 时，Cauchy 步是 1，全局解是 4.111。只用 Cauchy 步的方法本质上是最速下降，保留了收敛性，也保留了最速下降的慢。下面两种办法都从它出发，再往前走。

9.1 信赖域模型
9.2 子问题的求解
9.2.1 Cauchy 步
9.2.2 狗腿法
9.2.3 截断共轭梯度
9.3 步的接受与半径更新
9.4 收敛与计算成本
9.5 本章小结

9.2.2 狗腿法

主要思想 设 $\boldsymbol{B} \succ \boldsymbol{0}$。半径很小时，子问题的解贴近负梯度方向；半径足够大时，解就是 Newton 点。图 9.4中的绿线连接着这两端。求这条曲线要解久期方程，代价较高，**狗腿法**（dogleg method）用两段折线代替它。

折线的三个端点是原点、模型沿负梯度的最小点，以及 Newton 点：

$$\boldsymbol{p}^{\mathrm{U}} = -\frac{\boldsymbol{g}^{\top}\boldsymbol{g}}{\boldsymbol{g}^{\top}\boldsymbol{B}\boldsymbol{g}}\boldsymbol{g}, \qquad \boldsymbol{p}^{\mathrm{N}} = -\boldsymbol{B}^{-1}\boldsymbol{g}. \tag{9.15}$$

上标 U 表示无约束（unconstrained）。用 $\tau \in [0,2]$ 作路径的参数：

$$\boldsymbol{p}(\tau) = \begin{cases} \tau\,\boldsymbol{p}^{\mathrm{U}}, & 0 \le \tau \le 1, \\ \boldsymbol{p}^{\mathrm{U}} + (\tau - 1)(\boldsymbol{p}^{\mathrm{N}} - \boldsymbol{p}^{\mathrm{U}}), & 1 \le \tau \le 2. \end{cases} \tag{9.16}$$

狗腿法在这条路径上走，走到半径为止。这样做合理，要靠路径的两个性质：沿路径越走越远，模型值也越走越低。前者保证路径与球面至多相交一次，后者保证交点是路径上模型最低的可行点。图 9.9是点 $\boldsymbol{a}$ 上的这两条曲线，下面的引理给出证明。

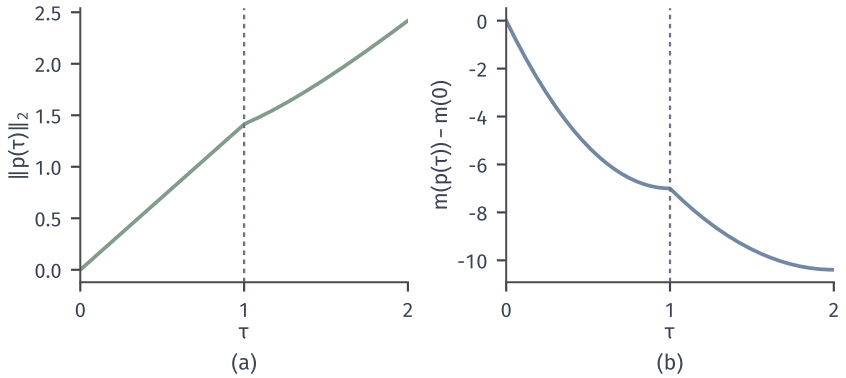


图 9.9 点 $\boldsymbol{a}$ 的数据上沿狗腿路径的两个量，虚线 $\tau = 1$ 是折点 $\boldsymbol{p}^{\mathrm{U}}$。(a) 长度严格增加。(b) 模型值严格减小。

引理 9.3 狗腿路径的单调性 设 $\boldsymbol{B} \succ \boldsymbol{0}, \boldsymbol{g} \neq \boldsymbol{0}$。沿路径 (9.16)，$\|\boldsymbol{p}(\tau)\|_2$ 单调不减，$m(\boldsymbol{p}(\tau))$ 单调不增。

证明 第一段上 $\boldsymbol{p}$ 是从原点出发的线段，长度递增；$\boldsymbol{p}^{\mathrm{U}}$ 是模型沿这条射线的最小点，模型值递减。

第二段记 $\boldsymbol{w}=\boldsymbol{p}^{\mathrm{N}}-\boldsymbol{p}^{\mathrm{U}}$，$s=\tau-1\in[0,1]$。先看模型值。$h(s)=m(\boldsymbol{p}^{\mathrm{U}}+s\boldsymbol{w})$ 是凸二次函数，它在 $s=1$ 处的导数是

$$h'(1)=\langle \boldsymbol{B}\boldsymbol{p}^{\mathrm{N}}+\boldsymbol{g},\boldsymbol{w}\rangle=0,$$

因为 $\boldsymbol{B}\boldsymbol{p}^{\mathrm{N}}=-\boldsymbol{g}$。凸函数的导数单调不减，所以在 $[0,1]$ 上 $h'\le 0$。

再看长度。$\frac{1}{2}\|\boldsymbol{p}^{\mathrm{U}}+s\boldsymbol{w}\|_2^2$ 对 s 的导数是 $\langle \boldsymbol{p}^{\mathrm{U}},\boldsymbol{w}\rangle+s\|\boldsymbol{w}\|_2^2$，只需证 $\langle \boldsymbol{p}^{\mathrm{U}},\boldsymbol{w}\rangle\ge 0$。记 $\tau_{\mathrm{U}}>0$ 为式 (9.15)中 $\boldsymbol{g}$ 前的系数，代入该式，得到

$$\langle \boldsymbol{p}^{\mathrm{U}},\boldsymbol{w}\rangle=\tau_{\mathrm{U}}\,\boldsymbol{g}^{\top}\boldsymbol{B}^{-1}\boldsymbol{g}-\tau_{\mathrm{U}}^{2}\,\boldsymbol{g}^{\top}\boldsymbol{g}=\frac{\tau_{\mathrm{U}}\big[(\boldsymbol{g}^{\top}\boldsymbol{B}^{-1}\boldsymbol{g})(\boldsymbol{g}^{\top}\boldsymbol{B}\boldsymbol{g})-(\boldsymbol{g}^{\top}\boldsymbol{g})^{2}\big]}{\boldsymbol{g}^{\top}\boldsymbol{B}\boldsymbol{g}}.$$

取 $\boldsymbol{u}=\boldsymbol{B}^{1/2}\boldsymbol{g}$，$\boldsymbol{v}=\boldsymbol{B}^{-1/2}\boldsymbol{g}$，方括号就是 $\|\boldsymbol{u}\|_2^2\|\boldsymbol{v}\|_2^2-\langle \boldsymbol{u},\boldsymbol{v}\rangle^2$，由 Cauchy–Schwarz 不等式非负。 ■

计算过程　下面用点 $\boldsymbol{a}$ 的数据 (9.3)、半径 $\Delta=2$ 走一遍。

需要的量是梯度 $\boldsymbol{g}\in\mathbb{R}^n$、对称正定矩阵 $\boldsymbol{B}\in\mathbb{R}^{n\times n}$、半径 Δ，输出位移 $\boldsymbol{p}$。例中已知 $\boldsymbol{g}=(7,7)^{\top}$，$\boldsymbol{B}=\mathrm{diag}(11,3)$。步骤如下。

1. 由式 (9.15)计算 Newton 点，若 $\|\boldsymbol{p}^{\mathrm{N}}\|_2\le\Delta$，返回 $\boldsymbol{p}=\boldsymbol{p}^{\mathrm{N}}$。例中

$$\boldsymbol{p}^{\mathrm{N}}=\begin{bmatrix}-7/11\\ -7/3\end{bmatrix},\qquad \|\boldsymbol{p}^{\mathrm{N}}\|_2\approx 2.419>2,$$

所以继续。

2. 由式 (9.15)计算 $\boldsymbol{p}^{\mathrm{U}}$，若 $\|\boldsymbol{p}^{\mathrm{U}}\|_2\ge\Delta$，返回边界上的负梯度步 $\boldsymbol{p}=-\Delta\boldsymbol{g}/\|\boldsymbol{g}\|_2$，这就是 Cauchy 步。例中

$$\boldsymbol{p}^{\mathrm{U}}=-\frac{98}{686}\begin{bmatrix}7\\7\end{bmatrix}=\begin{bmatrix}-1\\-1\end{bmatrix},\qquad \|\boldsymbol{p}^{\mathrm{U}}\|_2=\sqrt{2}<2,$$

所以继续。

3. 否则交点在第二段上。记 $\boldsymbol{w}=\boldsymbol{p}^{\mathrm{N}}-\boldsymbol{p}^{\mathrm{U}}$，解 $\|\boldsymbol{p}^{\mathrm{U}}+s\boldsymbol{w}\|_2=\Delta$ 的正根：

$$s=\frac{-\langle \boldsymbol{p}^{\mathrm{U}},\boldsymbol{w}\rangle+\sqrt{\langle \boldsymbol{p}^{\mathrm{U}},\boldsymbol{w}\rangle^2+\|\boldsymbol{w}\|_2^2\big(\Delta^2-\|\boldsymbol{p}^{\mathrm{U}}\|_2^2\big)}}{\|\boldsymbol{w}\|_2^2}.\tag{9.17}$$

例中 $\boldsymbol{w}=(4/11,\,-4/3)^{\top}$，三个系数是

$$\|\boldsymbol{w}\|_2^2=\frac{2080}{1089},\qquad \langle \boldsymbol{p}^{\mathrm{U}},\boldsymbol{w}\rangle=\frac{1056}{1089},\qquad \Delta^2-\|\boldsymbol{p}^{\mathrm{U}}\|_2^2=2.$$

根号内的量是 $(2376/1089)^2$，因此

$$s = \frac{-1056 + 2376}{2080} = \frac{33}{52}.$$

4. 返回 $\boldsymbol{p} = \boldsymbol{p}^{\mathrm{U}} + s\boldsymbol{w}$。例中

$$\boldsymbol{p} = \begin{bmatrix} -1 + 3/13 \\ -1 - 11/13 \end{bmatrix} = \begin{bmatrix} -10/13 \\ -24/13 \end{bmatrix},$$

长度恰为 $\sqrt{100 + 576}/13 = 2$。

最终得到的预测下降是

$$\mathrm{pred}(\boldsymbol{p}) = \frac{238}{13} - \frac{1414}{169} = \frac{1680}{169} \approx 9.941.$$

这已经是全局解 10.115 的 98%，而全局解要解一元非线性方程。图 9.10给出三种半径下的结果：$\Delta = 1$ 时只用到第一段，$\Delta = 2$ 时落在第二段，$\Delta = 3$ 时完整的 Newton 步被采用。

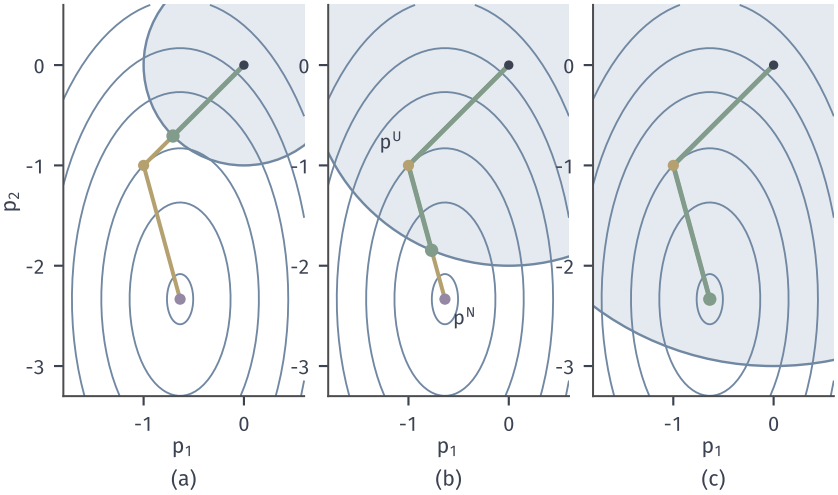


图 9.10　点 $\boldsymbol{a}$ 的数据上半径分别为 1、2、3 的狗腿步。黄线是完整路径，绿线是实际走过的部分，绿点是得到的步。黄点是 $\boldsymbol{p}^{\mathrm{U}}$，紫点是 $\boldsymbol{p}^{\mathrm{N}}$，蓝线是模型等高线，浅蓝圆盘是信赖域。

狗腿步的预测下降不低于 Cauchy 步：若 $\|\boldsymbol{p}^{\mathrm{U}}\|_2 \ge \Delta$，两者相同；否则 $\boldsymbol{p}^{\mathrm{U}}$ 本身就是 Cauchy 步，而由引理 9.3，狗腿步在路径上更靠后，模型值更低。所以它满足式 (9.14)，$c_1 = 1/2$。

不正定时不能照搬　上面的构造用到 $\boldsymbol{B} \succ \boldsymbol{0}$：$\boldsymbol{p}^{\mathrm{N}}$ 要是模型的最小点，第二段上的模型才会下降。把原点的数据 (9.4)照搬进去，$\boldsymbol{g}^{\top}\boldsymbol{B}\boldsymbol{g} = 2 > 0$，第

9.1 信赖域模型
9.2 子问题的求解
9.2.1 Cauchy 步
9.2.2 狗腿法
9.2.3 截断共轭梯度
9.3 步的接受与半径更新
9.4 收敛与计算成本
9.5 本章小结

一段还能算出 $\boldsymbol{p}^{\mathrm{U}} = (-1,-1)^{\mathsf{T}}$，第二段却指向鞍点 $(1,-1/3)^{\mathsf{T}}$。沿第二段模型上升，从 -1 一直升到 $1/3$，图 9.11画出了这一段。

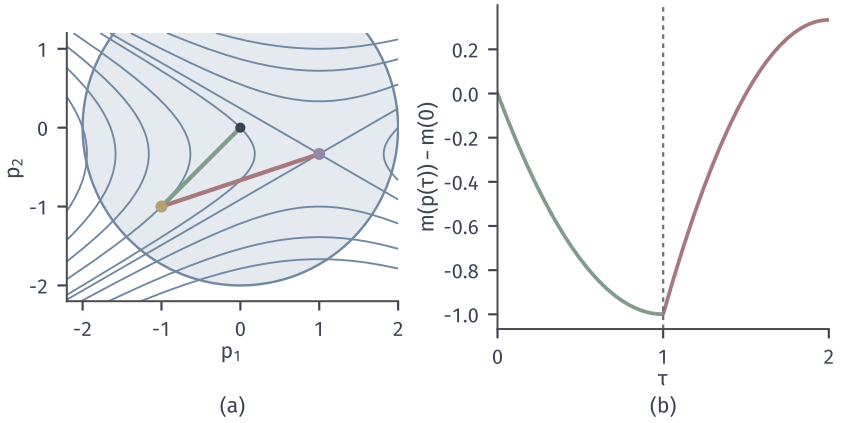


图 9.11 把狗腿路径照搬到原点的不定模型上。(a) 模型等高线（蓝）与路径：绿色第一段走向黄点 $\boldsymbol{p}^{\mathrm{U}}$，红色第二段走向模型的鞍点（紫）。(b) 沿路径的模型值，第二段（红）上升，路径上模型值的单调性失效。

$\boldsymbol{B}$ 半正定且奇异时，$\boldsymbol{B}^{-1}$ 不存在，构造同样失效。这时要么先把 $\boldsymbol{B}$ 修正成正定，要么换用下一小节的方法，后者不需要 $\boldsymbol{B}$ 的任何分解。

9.2.3 截断共轭梯度

主要思想 Newton 步是方程 $\boldsymbol{B}\boldsymbol{p} = -\boldsymbol{g}$ 的解，也就是模型的驻点。第 7章的 Newton-CG 用共轭梯度迭代近似解这个方程，只需要矩阵向量乘积。共轭梯度的推导和收敛性质可参考卷二第 15 章“Krylov 子空间法”，这里复述要用到的部分。

从 $\boldsymbol{p}^{(0)} = \boldsymbol{0}$ 出发，记残差 $\boldsymbol{r}^{(j)} = \boldsymbol{B}\boldsymbol{p}^{(j)} + \boldsymbol{g}$，它恰好是模型在 $\boldsymbol{p}^{(j)}$ 处的梯度。内层迭代的上标用 j，与外层的 t 区分。共轭梯度的递推是

$$
\begin{aligned}
\alpha^{(j)} &= \frac{\|\boldsymbol{r}^{(j)}\|_2^2}{\boldsymbol{d}^{(j)\mathsf{T}}\boldsymbol{B}\boldsymbol{d}^{(j)}}, \qquad \boldsymbol{p}^{(j+1)} = \boldsymbol{p}^{(j)} + \alpha^{(j)}\boldsymbol{d}^{(j)}, \\
&\qquad \boldsymbol{r}^{(j+1)} = \boldsymbol{r}^{(j)} + \alpha^{(j)}\boldsymbol{B}\boldsymbol{d}^{(j)}, \\
\beta^{(j)} &= \frac{\|\boldsymbol{r}^{(j+1)}\|_2^2}{\|\boldsymbol{r}^{(j)}\|_2^2}, \qquad \boldsymbol{d}^{(j+1)} = -\boldsymbol{r}^{(j+1)} + \beta^{(j)}\boldsymbol{d}^{(j)},
\end{aligned}
\tag{9.18}
$$

初始方向 $\boldsymbol{d}^{(0)} = -\boldsymbol{g}$。$\alpha^{(j)}$ 是模型沿 $\boldsymbol{d}^{(j)}$ 的精确一维最小点，所以每步模型值都下降。第一步恰好是 $\boldsymbol{p}^{\mathrm{U}}$。

放进信赖域，只需要回答两个新问题：迭代走出半径了怎么办，遇到 $\boldsymbol{B}$ 的非正曲率怎么办。**截断共轭梯度法**（truncated conjugate gradient method）的回答是：两种情况都沿当前方向走到边界，然后停止。

先看走出半径的情形。下面的引理说明，共轭梯度的迭代点离原点越来越远。一旦越出球，以后就不会回来，所以在第一次越界处截断不会错过后面的点。

引理 9.4　迭代点的长度递增　设 $\boldsymbol{g} \neq \boldsymbol{0}$，递推 (9.18)进行到第 j 步，且此前各步曲率 $\boldsymbol{d}^{(i)\top}\boldsymbol{B}\boldsymbol{d}^{(i)} > 0$，残差非零。则

$$\|\boldsymbol{p}^{(j+1)}\|_2 > \|\boldsymbol{p}^{(j)}\|_2. \tag{9.19}$$

证明　残差相互正交，并且方向与残差张成同一子空间：

$$\operatorname{span}\{\boldsymbol{d}^{(0)}, \dots, \boldsymbol{d}^{(j-1)}\} = \operatorname{span}\{\boldsymbol{r}^{(0)}, \dots, \boldsymbol{r}^{(j-1)}\}.$$

这两条性质的归纳证明只用到递推 (9.18)中的分母非零，不要求 $\boldsymbol{B}$ 在全空间正定。由于 $\boldsymbol{p}^{(j)}$ 是 $\boldsymbol{d}^{(0)}, \dots, \boldsymbol{d}^{(j-1)}$ 的线性组合，所以 $\langle \boldsymbol{p}^{(j)}, \boldsymbol{r}^{(j)} \rangle = 0$。

用归纳法证明 $\langle \boldsymbol{p}^{(j)}, \boldsymbol{d}^{(j)} \rangle \geq 0$。$j = 0$ 时等于 0。代入 $\boldsymbol{d}^{(j+1)}$ 的定义，并用正交性，得到

$$\langle \boldsymbol{p}^{(j+1)}, \boldsymbol{d}^{(j+1)} \rangle = \beta^{(j)} \langle \boldsymbol{p}^{(j+1)}, \boldsymbol{d}^{(j)} \rangle = \beta^{(j)} \big(\langle \boldsymbol{p}^{(j)}, \boldsymbol{d}^{(j)} \rangle + \alpha^{(j)} \|\boldsymbol{d}^{(j)}\|_2^2 \big),$$

其中 $\alpha^{(j)}, \beta^{(j)} > 0$，因此它非负。

最后展开长度：

$$\|\boldsymbol{p}^{(j+1)}\|_2^2 = \|\boldsymbol{p}^{(j)}\|_2^2 + 2\alpha^{(j)} \langle \boldsymbol{p}^{(j)}, \boldsymbol{d}^{(j)} \rangle + (\alpha^{(j)})^2 \|\boldsymbol{d}^{(j)}\|_2^2 > \|\boldsymbol{p}^{(j)}\|_2^2.$$

■

再看非正曲率的情形。若 $\boldsymbol{d}^{(j)\top}\boldsymbol{B}\boldsymbol{d}^{(j)} \leq 0$，模型沿 $\boldsymbol{d}^{(j)}$ 是凹的。由 $\boldsymbol{r}^{(j)}$ 与 $\boldsymbol{d}^{(j-1)}$ 正交可知模型沿 $\boldsymbol{d}^{(j)}$ 的斜率为 $-\|\boldsymbol{r}^{(j)}\|_2^2 < 0$，所以越往前走模型越低，应当一直走到边界。这正是第 9.1节所说的利用负曲率。

三种停止各有含义，图 9.12是一步迭代的判断顺序。残差停止表示模型的驻点已经解得够准，判据沿用第 7章非精确 Newton 法的形式：

$$\|\boldsymbol{r}^{(j)}\|_2 \leq \eta \|\boldsymbol{g}\|_2, \qquad \eta = \min\{0.1, \sqrt{\|\boldsymbol{g}\|_2}\}. \tag{9.20}$$

边界停止表示模型的最小点在球外。曲率停止表示模型沿这个方向没有最小点。后两条是信赖域给内层迭代新加的规则，Newton-CG 遇到非正曲率时只能退回一个下降方向，交给线搜索。

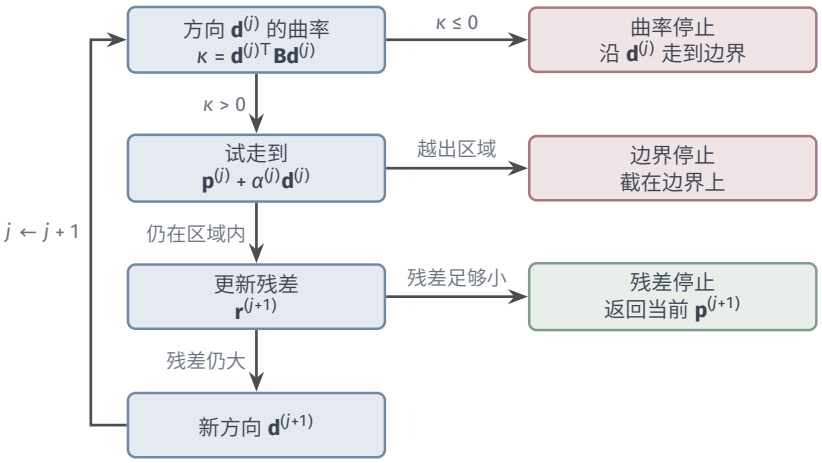


图 9.12 截断共轭梯度一次内层迭代的判断顺序。蓝框是普通的共轭梯度步骤，红框是信赖域带来的两种截断，绿框是沿用 Newton-CG 的残差停止。

变量 下面的过程结合点 $\boldsymbol{a}$ 的数据走一遍，要维护的量是：

- $\boldsymbol{p}^{(j)} \in \mathbb{R}^n$：当前位移；
- $\boldsymbol{r}^{(j)} \in \mathbb{R}^n$：模型在 $\boldsymbol{p}^{(j)}$ 处的梯度；
- $\boldsymbol{d}^{(j)} \in \mathbb{R}^n$：搜索方向；
- $\boldsymbol{B}\boldsymbol{d}^{(j)} \in \mathbb{R}^n$：一次矩阵向量乘积，是全部需要的曲率信息。

初始化 取 $\boldsymbol{p}^{(0)} = \boldsymbol{0}$，$\boldsymbol{r}^{(0)} = \boldsymbol{g}$，$\boldsymbol{d}^{(0)} = -\boldsymbol{g}$，容差 η。例中半径 $\Delta = 2$，容差取 $\eta = 0.1$：

$$\boldsymbol{r}^{(0)} = \begin{bmatrix} 7 \\ 7 \end{bmatrix}, \qquad \boldsymbol{d}^{(0)} = \begin{bmatrix} -7 \\ -7 \end{bmatrix}, \qquad \eta \|\boldsymbol{g}\|_2 \approx 0.990.$$

每轮更新 第 j 轮依次执行以下步骤。

1. 计算 $\boldsymbol{B}\boldsymbol{d}^{(j)}$ 和曲率 $\boldsymbol{d}^{(j)\mathsf{T}}\boldsymbol{B}\boldsymbol{d}^{(j)}$。若曲率不大于零，按式 (9.17)（其中 $\boldsymbol{p}^{\mathrm{U}}$ 换成 $\boldsymbol{p}^{(j)}$，$\boldsymbol{w}$ 换成 $\boldsymbol{d}^{(j)}$）求出边界上的 σ，返回 $\boldsymbol{p}^{(j)} + \sigma \boldsymbol{d}^{(j)}$。例中第一轮

$$\boldsymbol{B}\boldsymbol{d}^{(0)} = \begin{bmatrix} -77 \\ -21 \end{bmatrix}, \qquad \boldsymbol{d}^{(0)\mathsf{T}}\boldsymbol{B}\boldsymbol{d}^{(0)} = 686 > 0.$$

2. 由式 (9.18)计算 $\alpha^{(j)}$ 和试探点 $\boldsymbol{p}^{(j)} + \alpha^{(j)}\boldsymbol{d}^{(j)}$。若试探点的长度不小于 Δ，同样求边界上的 σ 并返回。例中第一轮

$$\alpha^{(0)} = \frac{98}{686} = \frac{1}{7}, \qquad \boldsymbol{p}^{(1)} = \begin{bmatrix} -1 \\ -1 \end{bmatrix}, \qquad \|\boldsymbol{p}^{(1)}\|_2 = \sqrt{2} < 2.$$

3. 由式 (9.18)更新残差，若 $\boldsymbol{r}^{(j+1)}$ 满足式 (9.20)，返回 $\boldsymbol{p}^{(j+1)}$。例中第一轮

$$\boldsymbol{r}^{(1)} = \begin{bmatrix} 7 \\ 7 \end{bmatrix} + \frac{1}{7}\begin{bmatrix} -77 \\ -21 \end{bmatrix} = \begin{bmatrix} -4 \\ 4 \end{bmatrix}, \qquad \|\boldsymbol{r}^{(1)}\|_2 \approx 5.66 > 0.990.$$

4. 由式 (9.18)计算 $\beta^{(j)}$ 和新方向。例中第一轮

$$\beta^{(0)} = \frac{32}{98} = \frac{16}{49}, \qquad \boldsymbol{d}^{(1)} = \begin{bmatrix} 4 \\ -4 \end{bmatrix} + \frac{16}{49}\begin{bmatrix} -7 \\ -7 \end{bmatrix} = \begin{bmatrix} 12/7 \\ -44/7 \end{bmatrix}.$$

例中第二轮的曲率是

$$\boldsymbol{B}\boldsymbol{d}^{(1)} = \begin{bmatrix} 132/7 \\ -132/7 \end{bmatrix}, \qquad \boldsymbol{d}^{(1)\mathsf{T}}\boldsymbol{B}\boldsymbol{d}^{(1)} = \frac{7392}{49} > 0.$$

于是 $\alpha^{(1)} = 32 \cdot 49/7392 = 7/33$。试探点正是 Newton 点，而它的长度约为 2.419，超过了半径：

$$\boldsymbol{p}^{(1)} + \alpha^{(1)}\boldsymbol{d}^{(1)} = \begin{bmatrix} -7/11 \\ -7/3 \end{bmatrix}.$$

所以按边界停止。由式 (9.17)，边界上的 $\sigma = 7/52$，最终得到

$$\boldsymbol{p} = \begin{bmatrix} -1 \\ -1 \end{bmatrix} + \frac{7}{52}\begin{bmatrix} 12/7 \\ -44/7 \end{bmatrix} = \begin{bmatrix} -10/13 \\ -24/13 \end{bmatrix}.$$

这和狗腿步完全相同，并不是巧合。二维时共轭梯度第一步到 $\boldsymbol{p}^{\mathrm{U}}$，第二步到 $\boldsymbol{p}^{\mathrm{N}}$，两段路径就是狗腿路径。维数大于 2 时两者不同：狗腿法从 $\boldsymbol{p}^{\mathrm{U}}$ 直奔 Newton 点，截断共轭梯度沿途经过一串中间点，也不需要预先分解 $\boldsymbol{B}$。半径若取 $\Delta = 3$，第二轮的试探点在球内，残差恰好为零，按残差停止，返回 Newton 步。

再用原点的数据 (9.4)、$\Delta = 2$ 看曲率停止。第一轮的曲率 $\boldsymbol{d}^{(0)\mathsf{T}}\boldsymbol{B}\boldsymbol{d}^{(0)} = 2 > 0$，$\alpha^{(0)} = 1$，试探点在球内，并有

$$\boldsymbol{p}^{(1)} = \begin{bmatrix} -1 \\ -1 \end{bmatrix}, \qquad \boldsymbol{r}^{(1)} = \begin{bmatrix} 2 \\ -2 \end{bmatrix}, \qquad \boldsymbol{d}^{(1)} = \begin{bmatrix} -6 \\ -2 \end{bmatrix}.$$

第二轮的曲率是 $-36 + 12 = -24 \le 0$，沿 $\boldsymbol{d}^{(1)}$ 走到边界。由 $\|\boldsymbol{p}^{(1)} + \sigma\boldsymbol{d}^{(1)}\|_2 = 2$ 得 $20\sigma^2 + 8\sigma - 1 = 0$，取正根 $\sigma = 1/10$，最终得到

$$\boldsymbol{p} = \begin{bmatrix} -8/5 \\ -6/5 \end{bmatrix}, \qquad \mathrm{pred}(\boldsymbol{p}) = \frac{48}{25} = 1.92.$$

图 9.13是这两次运行的轨迹。

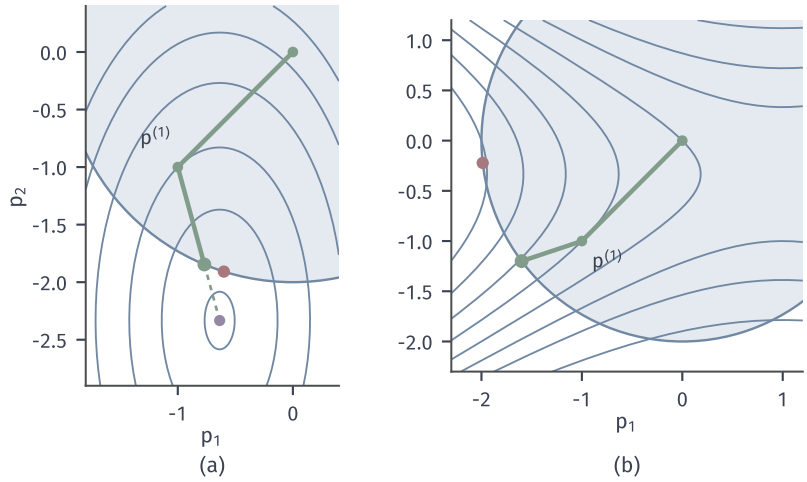


图 9.13　截断共轭梯度的两次运行，绿线是迭代轨迹，绿色大点是返回的步，红点是子问题的全局解。(a) 点 $\boldsymbol{a}$，第二轮越过边界而截断，虚线通向球外的 Newton 点（紫）。(b) 原点，第二轮遇到负曲率，沿方向走到边界。

算法分析　截断共轭梯度的第一轮要么到达 $\boldsymbol{p}^{\mathrm{U}}$，要么在边界上截断，得到的都是 Cauchy 步，此后每一步模型值都不升高：普通步是精确一维最小化，边界截断发生在模型仍然下降的路段上。所以它的预测下降不低于 Cauchy 步，满足式 (9.14)，$c_1 = 1/2$。

当 $\boldsymbol{B} \succ \boldsymbol{0}$ 时还可以证明，截断共轭梯度的预测下降至少是全局解的一半，证明需要细致比较 Krylov 子空间上的子问题，篇幅较长，读者可查阅专门的信赖域文献。$\boldsymbol{B}$ 不定时没有这个保证：原点上它的预测下降只有 1.92，全局解是 4.111。它在图 9.13(b) 中沿方向 $(-3,-1)^{\mathsf{T}}$ 走到边界，错过了曲率最负的方向 $\boldsymbol{e}_1$。

表 9.2汇总同一个模型上三种步和全局解的结果。

模型	量	Cauchy 步	狗腿步	截断共轭梯度	全局解
点 $\boldsymbol{a}$	pred	7.000	9.941	9.941	10.115
	ared	8.750	10.764	10.764	10.515
原点	pred	1.000	不适用	1.920	4.111
	ared	0.750	不适用	0.282	0.209

表 9.2　半径 $\Delta = 2$ 时几种步的预测下降与实际下降。

二维例子看不出截断共轭梯度的省力之处。图 9.14取一个 $n = 200$ 的正定模型：Hessian 向量乘积只用 9 次，预测下降就达到全局解的 98%，长度

9.1 信赖域模型
9.2 子问题的求解
9.3 步的接受与半径更新
9.4 收敛与计算成本
9.5 本章小结

随次数严格增加，与引理 9.4一致。这时狗腿法和精确求解都要作 200 阶矩阵的分解。

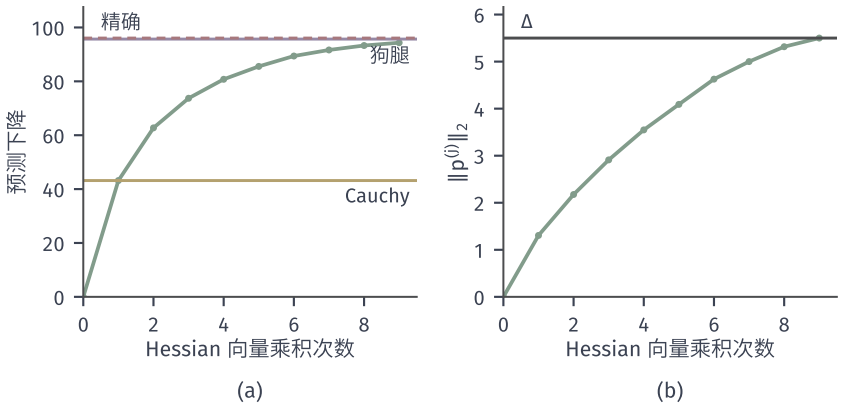


图 9.14 一个 $n = 200$ 的随机正定模型，特征值在 1 到 100 之间对数等距，$\Delta = 5.5$，随机种子固定。(a) 截断共轭梯度（绿）的预测下降随矩阵向量乘积次数的变化，水平线依次为 Cauchy 步（黄）、狗腿步（紫）和全局解（红虚线）。(b) 迭代点长度（绿）递增，触及半径（深灰线）时停止。

9.3 步的接受与半径更新

子问题给出了一个候选步，但模型的话不能全信。这就需要回答：怎样用真实目标检验这一步，并决定下一轮用多大的半径？

主要思想 第 9.1节已经分开了预测下降和实际下降，把它们相除就是一个无量纲的检验量。定义**下降比**（reduction ratio）：

$$\rho^{(t)} = \frac{\operatorname{ared}(\boldsymbol{p}^{(t)})}{\operatorname{pred}(\boldsymbol{p}^{(t)})} = \frac{f(\boldsymbol{x}^{(t)}) - f(\boldsymbol{x}^{(t)} + \boldsymbol{p}^{(t)})}{m^{(t)}(\boldsymbol{0}) - m^{(t)}(\boldsymbol{p}^{(t)})}. \tag{9.21}$$

只要 $\boldsymbol{g}^{(t)} \neq \boldsymbol{0}$ 且候选步满足式 (9.14)，分母就为正，比值有意义。

$\rho^{(t)}$ 接近 1，说明模型在这个范围内预测得准。$\rho^{(t)}$ 是很小的正数，说明目标虽有下降，但比预测差得多。$\rho^{(t)}$ 为负，说明目标实际上升了。$\rho^{(t)}$ 大于 1，说明目标比模型预测的下降更多，这是好事，但也表明模型并不精确。

用两个阈值 $0 < \eta_1 \le \eta_2 < 1$ 把数轴分成三段，常取 $\eta_1 = 1/4$，$\eta_2 = 3/4$；另取缩小因子 $\theta \in (0,1)$ 和半径上限 $\Delta_{\max}$。下一个点按是否接受决定：

$$\boldsymbol{x}^{(t+1)} = \begin{cases} \boldsymbol{x}^{(t)} + \boldsymbol{p}^{(t)}, & \rho^{(t)} \ge \eta_1, \\ \boldsymbol{x}^{(t)}, & \rho^{(t)} < \eta_1. \end{cases} \tag{9.22}$$

下一轮的半径按模型的表现决定：

$$\Delta^{(t+1)} = \begin{cases} \theta\Delta^{(t)}, & \rho^{(t)} < \eta_1, \\ \min\{2\Delta^{(t)}, \Delta_{\max}\}, & \rho^{(t)} \geq \eta_2 \text{ 且步在边界}, \\ \Delta^{(t)}, & \text{其他情形}. \end{cases} \tag{9.23}$$

第二种情形多了“步在边界”这个条件，即 $\|\boldsymbol{p}^{(t)}\|_2 = \Delta^{(t)}$：若步在球内部，半径并没有限制住它，扩大半径没有意义。图 9.15把这三段画在数轴上。

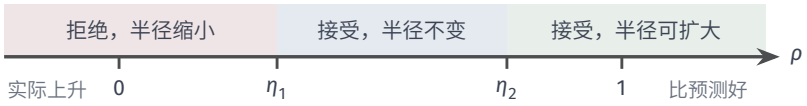


图 9.15 下降比 ρ 的三段及相应动作。红色段拒绝这一步，蓝色段接受但半径不变，绿色段接受，并且在步到达边界时扩大半径。

拒绝一步的代价比看上去小。点没有动，梯度和 $\boldsymbol{B}$ 都不用重算，下一轮用同一个模型在更小的球里重解子问题。这里要与线搜索的回溯对比：回溯只缩短长度，方向不变；信赖域缩小半径后，新的解方向一般也变了。图 9.16是完整的一轮。

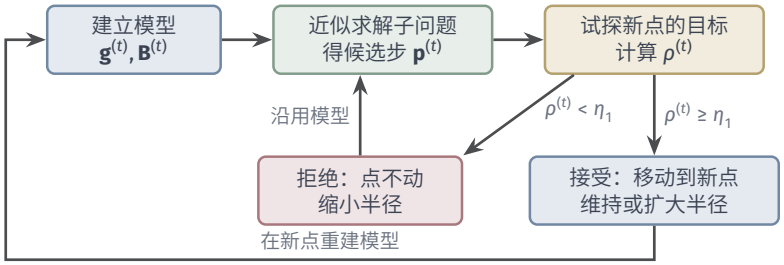


图 9.16 信赖域方法的一轮。黄框里的目标值是这一轮唯一一次新增的函数值计算。接受时回到左侧在新点重建模型，拒绝时模型沿用，只在更小的球内重解子问题。

模型矩阵从哪里来 框架对 $\boldsymbol{B}^{(t)}$ 的要求很少：对称，范数有界。取 Hessian 得到信赖域 Newton 法；取第 8章的 BFGS 近似也可以。第 8章的 SR1 更新尤其适合这里，它由位移 $\boldsymbol{s} = \boldsymbol{p}^{(t)}$ 和梯度差 $\boldsymbol{y}$ 得到

$$\boldsymbol{B}^{(t+1)} = \boldsymbol{B}^{(t)} + \frac{(\boldsymbol{y} - \boldsymbol{B}^{(t)}\boldsymbol{s})(\boldsymbol{y} - \boldsymbol{B}^{(t)}\boldsymbol{s})^{\mathsf{T}}}{\langle \boldsymbol{y} - \boldsymbol{B}^{(t)}\boldsymbol{s}, \boldsymbol{s} \rangle}. \tag{9.24}$$

SR1 不保持正定性，$\boldsymbol{B}^{(t+1)}$ 可能不定，放进线搜索框架时方向可能不是下降方向，这在信赖域中不成问题。分母过小时跳过更新。即使这一步被

拒绝，$\boldsymbol{s}$ 和 $\boldsymbol{y}$ 仍然是真实的曲率信息，通常也用来更新，代价是在试探点多算一次梯度。这时 $\boldsymbol{B}^{(t)}$ 已不是 $\boldsymbol{H}^{(t)}$，下面的手算例子仍用 Hessian。

变量　下面用目标 (9.1)走完整个过程，子问题用截断共轭梯度求解。要维护的量是：

- $\boldsymbol{x}^{(t)} \in \mathbb{R}^n$：当前点，$f(\boldsymbol{x}^{(t)})$ 是它的目标值；
- $\Delta^{(t)} > 0$：当前半径；
- $\boldsymbol{g}^{(t)} \in \mathbb{R}^n$，$\boldsymbol{B}^{(t)} \in \mathbb{R}^{n\times n}$：当前模型，上一轮被拒绝时直接沿用。

初始化　选定 $\boldsymbol{x}^{(0)}$，$\Delta^{(0)}$，阈值和缩小因子。例中取

$$\boldsymbol{x}^{(0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \qquad \Delta^{(0)} = 2, \qquad \Delta_{\max} = 8,$$

$$\eta_1 = \frac{1}{4}, \qquad \eta_2 = \frac{3}{4}, \qquad \theta = \frac{1}{2}.$$

每轮更新　第 t 轮依次执行以下步骤，直到 $\|\boldsymbol{g}^{(t)}\|_2$ 小于给定的容差。

1. 若上一轮接受了步，由式 (9.2)计算 $\boldsymbol{g}^{(t)}$ 和 $\boldsymbol{B}^{(t)}$。例中第 0 轮得到数据 (9.4)。

2. 近似求解子问题 (9.7)，得到 $\boldsymbol{p}^{(t)}$。例中第 0 轮就是上一节算过的曲率停止：
$$\boldsymbol{p}^{(0)} = \begin{bmatrix} -1.6 \\ -1.2 \end{bmatrix}, \qquad \operatorname{pred}(\boldsymbol{p}^{(0)}) = 1.92.$$

3. 由式 (9.21)计算 $\rho^{(t)}$。例中第 0 轮由式 (9.6)，模型误差是 $\frac{1}{4}(1.6)^4 = 1.6384$，于是
$$\operatorname{ared}(\boldsymbol{p}^{(0)}) = 1.92 - 1.6384 = 0.2816, \qquad \rho^{(0)} \approx 0.147.$$

4. 由式 (9.22)和式 (9.23)决定下一个点和半径。例中第 0 轮 $\rho^{(0)} < 1/4$，拒绝这一步，并有
$$\boldsymbol{x}^{(1)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \qquad \Delta^{(1)} = 1.$$

第 1 轮沿用同一个模型。半径变成 1，共轭梯度的第一步 $(-1,-1)^{\mathsf{T}}$ 长度为 $\sqrt{2}$，已越过边界，所以截断在球面上：

$$\boldsymbol{p}^{(1)} = \begin{bmatrix} -1/\sqrt{2} \\ -1/\sqrt{2} \end{bmatrix}, \qquad \operatorname{pred}(\boldsymbol{p}^{(1)}) = \sqrt{2} - \frac{1}{2} \approx 0.9142.$$

模型误差是 $\frac{1}{4}(1/\sqrt{2})^4 = 0.0625$，于是实际下降约为 0.8517，比值 $\rho^{(1)} \approx 0.932 \geq 3/4$。这一步在边界上，接受并把半径扩大：

$$\boldsymbol{x}^{(2)} \approx \begin{bmatrix} -0.7071 \\ -0.7071 \end{bmatrix}, \qquad \Delta^{(2)} = 2.$$

半径减半之后，步的方向由 $(-1.6, -1.2)$ 变成了负梯度方向，这正是前面说的方向随半径变化。图 9.17把这两次试探画在真实目标上。

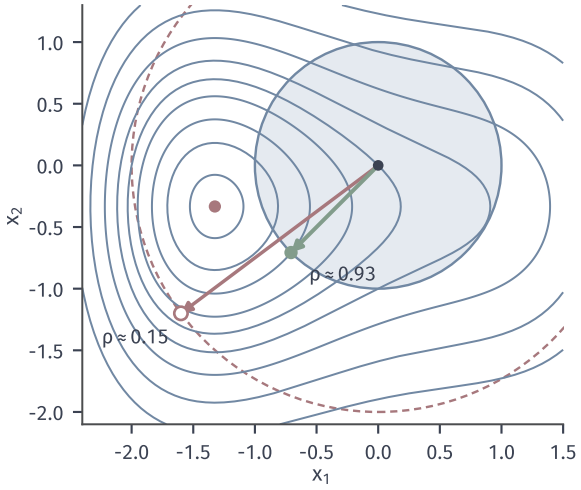


图 9.17 原点处的一次拒绝与一次接受，蓝线是目标 (9.1)的等高线。红色虚线圆和红色箭头是 $\Delta = 2$ 的试探，空心点被拒绝；浅蓝圆盘和绿色箭头是 $\Delta = 1$ 的试探，绿点被接受。红色实心点是最小点。

第 2 轮由式 (9.2)重建模型：

$$\boldsymbol{g}^{(2)} \approx \begin{bmatrix} 1.3536 \\ -1.1213 \end{bmatrix}, \qquad \boldsymbol{B}^{(2)} \approx \begin{bmatrix} 0.5 & 0 \\ 0 & 3 \end{bmatrix}.$$

这时 $\boldsymbol{B}$ 已经正定，但 x_1 方向的曲率只有 0.5，比前方实际的曲率小得多。$\Delta = 2$ 的步是 $\boldsymbol{p}^{(2)} \approx (-1.928, 0.530)^{\mathsf{T}}$，预测下降 1.853，实际却上升 6.674，$\rho^{(2)} \approx -3.60$，又被拒绝。第 3 轮半径减半后，比值回到 0.589，接受，半径保持为 1。

继续下去，第 4 轮开始 Newton 步已落在球内，由残差停止，半径不再起作用，比值接近 1，梯度范数迅速下降。表 9.3列出全部 8 轮，最终得到 $\boldsymbol{x} \approx (-1.3247, -0.3333)^{\mathsf{T}}$，$f \approx -1.5989$，这就是 $\boldsymbol{x}^{\star}$。图 9.18是轨迹和半径的变化。

9.1　信赖域模型
9.2　子问题的求解
9.3　步的接受与半径更新
9.4　收敛与计算成本
9.5　本章小结

t	$f(\boldsymbol{x}^{(t)})$	$\Delta^{(t)}$	停止	pred	ared	$\rho^{(t)}$	结果
0	0.000	2	曲率	1.920	0.282	0.147	拒绝
1	0.000	1	边界	0.914	0.852	0.932	接受，扩大
2	−0.852	2	边界	1.853	−6.674	−3.602	拒绝
3	−0.852	1	边界	0.999	0.588	0.589	接受
4	−1.440	1	残差	0.155	0.158	1.023	接受
5	−1.598	1	残差	0.001	0.001	1.011	接受
6	−1.599	1	残差	0.000	0.000	1.000	接受
7	−1.599	1	残差	0.000	0.000	0.999	接受

表 9.3　贯穿例子的完整运行。pred 和 ared 是预测下降与实际下降，“停止”是内层截断共轭梯度的停止原因。

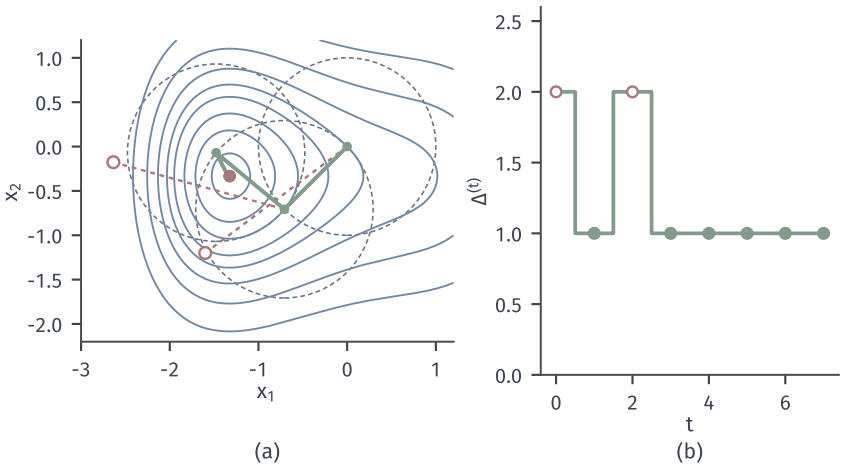


图 9.18　贯穿例子的完整运行。(a) 目标等高线（蓝）上的轨迹（绿），虚线圆是前几轮被接受时的信赖域，红色虚线和空心点是被拒绝的试探，红点是最小点。(b) 半径随轮数的变化，实心点表示接受，空心点表示拒绝。

这次运行显示了框架的分工：远离解时，半径起主导作用，负责把模型限制在可信的范围；靠近解时，半径不再起作用，方法退化成普通的 Newton 法。半径的调整不需要人工干预，由下降比自动完成。

9.4　收敛与计算成本

前几节的例子看起来都收敛了，在什么条件下这是必然的，极限点是什么样的点，每一轮又要花多少计算？

假设　一阶结果需要下面三条假设。

1. f 连续可微，下有界，$f \ge f_{\mathrm{low}}$，梯度在 $\mathbb{R}^n$ 上 Lipschitz 连续，常数为 L。

2. 模型矩阵一致有界：$\boldsymbol{B}^{(t)}$ 对称，$\|\boldsymbol{B}^{(t)}\|_2 \le M$，$M > 0$。

3. 候选步可行，$\|\boldsymbol{p}^{(t)}\|_2 \le \Delta^{(t)}$，并且对某个 $c_1 \in (0, 1]$ 满足充分模型下降：

$$\operatorname{pred}(\boldsymbol{p}^{(t)}) \ge c_1 \|\boldsymbol{g}^{(t)}\|_2 \min\Big\{\Delta^{(t)}, \frac{\|\boldsymbol{g}^{(t)}\|_2}{M}\Big\}. \tag{9.25}$$

第三条由式 (9.14)和 $\|\boldsymbol{B}^{(t)}\|_2 \le M$ 推出，前面三种求解器都满足。第一条的全局 Lipschitz 条件可以放宽：目标 (9.1)的梯度不是全局 Lipschitz 的，但它的水平集有界，半径又有上限 $\Delta_{\max}$，试探点都落在一个紧集内，L 只需在这个紧集上成立。

条件里没有要求 $\boldsymbol{B}^{(t)}$ 接近 Hessian，也没有要求子问题解得精确。模型只要在一阶上与目标匹配，这正是拟牛顿模型能够进入这个框架的原因。

半径不会塌缩　证明的核心是一个观察：半径足够小时，模型误差相对预测下降可以忽略，这一步一定被接受。模型误差是半径的二次量，预测下降却是半径的一次量，两者之比随半径趋于零。图 9.19在点 $\boldsymbol{a}$ 上验证了这一点：取精确 Hessian 时 $|1-\rho|$ 随半径的斜率是 2，取粗糙的 $\boldsymbol{B} = \boldsymbol{I}$ 时斜率是 1，后者正是定理使用的一般界。

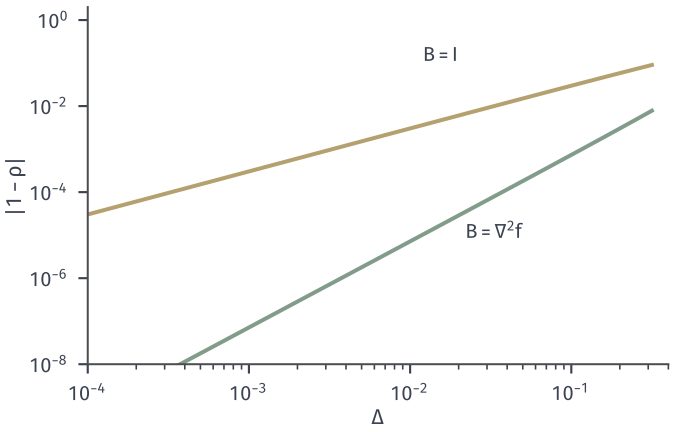


图 9.19　在点 $\boldsymbol{a}$ 沿负梯度方向取长度 Δ 的步，$|1-\rho|$ 随 Δ 的变化（对数坐标）。绿线的模型矩阵是 Hessian，斜率约为 2；黄线的模型矩阵是 $\boldsymbol{I}$，斜率约为 1。两条线都随 $\Delta \to 0$ 趋于零。

定理 9.5　梯度的下极限为零　在上述三条假设下，设外层迭代按式 (9.22)和式 (9.23)更新，其中 $\eta_1 > 0$。此时

$$\liminf_{t \to \infty} \|\boldsymbol{g}^{(t)}\|_2 = 0. \tag{9.26}$$

证明 反设存在 $\varepsilon > 0$ 和 T_0，使得 $t \ge T_0$ 时 $\|\boldsymbol{g}^{(t)}\|_2 \ge \varepsilon$。

第一步估计模型误差。由梯度 Lipschitz 连续，对任意 $\boldsymbol{p}$，

$$\left| f(\boldsymbol{x}+\boldsymbol{p}) - f(\boldsymbol{x}) - \langle \boldsymbol{g}, \boldsymbol{p}\rangle \right| = \left| \int_0^1 \langle \nabla f(\boldsymbol{x}+s\boldsymbol{p}) - \boldsymbol{g}, \boldsymbol{p}\rangle \,\mathrm{d}s \right| \le \frac{L}{2}\|\boldsymbol{p}\|_2^2.$$

再计入模型的二次项，且 $\|\boldsymbol{p}^{(t)}\|_2 \le \Delta^{(t)}$，得到

$$\left| f(\boldsymbol{x}^{(t)}+\boldsymbol{p}^{(t)}) - m^{(t)}(\boldsymbol{p}^{(t)}) \right| \le \frac{L+M}{2}(\Delta^{(t)})^2.$$

第二步说明小半径时不会缩小。令

$$K = \min\left\{ \frac{1}{M},\ \frac{2c_1(1-\eta_2)}{L+M} \right\}.$$

设 $t \ge T_0$ 且 $\Delta^{(t)} \le K\varepsilon$。此时 $\Delta^{(t)} \le \varepsilon/M$，不超过 $\|\boldsymbol{g}^{(t)}\|_2/M$，所以式 (9.25)的最小值取在 $\Delta^{(t)}$ 上：

$$\mathrm{pred}(\boldsymbol{p}^{(t)}) \ge c_1 \varepsilon \Delta^{(t)}.$$

又 $m^{(t)}(\boldsymbol{0}) = f(\boldsymbol{x}^{(t)})$，所以预测下降与实际下降之差就是模型误差，于是

$$|1-\rho^{(t)}| \le \frac{(L+M)(\Delta^{(t)})^2/2}{c_1\varepsilon\Delta^{(t)}} = \frac{(L+M)\Delta^{(t)}}{2c_1\varepsilon} \le 1-\eta_2.$$

因此 $\rho^{(t)} \ge \eta_2 \ge \eta_1$，这一轮半径不缩小。

第三步得到半径的下界。半径只在 $\Delta^{(t)} > K\varepsilon$ 时才可能缩小，缩小后不低于 $\theta K\varepsilon$，所以对 $t \ge T_0$，

$$\Delta^{(t)} \ge \Delta_{\min} := \min\{\Delta^{(T_0)},\ \theta K\varepsilon\} > 0.$$

第四步导出矛盾。若被接受的轮只有有限多次，则此后点不动，半径每轮乘以 θ，趋于零，与下界矛盾。所以接受无穷多次，每次接受时 $\rho^{(t)} \ge \eta_1$，并由式 (9.25)，

$$f(\boldsymbol{x}^{(t)}) - f(\boldsymbol{x}^{(t+1)}) \ge \eta_1 \,\mathrm{pred}(\boldsymbol{p}^{(t)}) \ge \eta_1 c_1 \varepsilon \min\left\{ \Delta_{\min},\ \frac{\varepsilon}{M} \right\} > 0.$$

目标值单调不增，却无穷多次下降一个固定的量，这与 $f \ge f_{\mathrm{low}}$ 矛盾。 ■

下极限只说明有一个子列的梯度趋于零。$\eta_1 > 0$ 时可以加强：整个序列的梯度都趋于零。

定理 9.6 梯度趋于零 在定理 9.5的条件下，

$$\lim_{t\to\infty}\|\boldsymbol{g}^{(t)}\|_2 = 0. \tag{9.27}$$

证明 反设存在 $\varepsilon > 0$ 和无穷多个下标 t 满足 $\|\boldsymbol{g}^{(t)}\|_2 \geq 2\varepsilon$。对每个这样的 t，由定理 9.5，存在最小的 $l(t) > t$ 使 $\|\boldsymbol{g}^{(l(t))}\|_2 < \varepsilon$。在 $t \leq k < l(t)$ 的轮中 $\|\boldsymbol{g}^{(k)}\|_2 \geq \varepsilon$。记其中被接受的轮的集合为 $\mathcal{K}$。

由 Lipschitz 条件和 $\|\boldsymbol{p}^{(k)}\|_2 \leq \Delta^{(k)}$，这段路程的总长度不能太短：

$$\varepsilon \leq \|\boldsymbol{g}^{(t)}\|_2 - \|\boldsymbol{g}^{(l(t))}\|_2 \leq L\sum_{k\in\mathcal{K}}\|\boldsymbol{p}^{(k)}\|_2 \leq L\sum_{k\in\mathcal{K}}\Delta^{(k)}.$$

这段路程上目标的下降量由接受规则和式 (9.25)控制：

$$f(\boldsymbol{x}^{(t)}) - f(\boldsymbol{x}^{(l(t))}) \geq \eta_1 c_1 \varepsilon \sum_{k\in\mathcal{K}} \min\Big\{\Delta^{(k)},\ \frac{\varepsilon}{M}\Big\}.$$

若 $\mathcal{K}$ 中某一项有 $\Delta^{(k)} > \varepsilon/M$，右端至少是 $\eta_1 c_1 \varepsilon^2/M$。否则右端等于 $\eta_1 c_1 \varepsilon \sum \Delta^{(k)}$，至少是 $\eta_1 c_1 \varepsilon^2/L$。两种情形下降量都有一个不依赖 t 的正下界。但 $f(\boldsymbol{x}^{(t)})$ 单调且有下界，$t\to\infty$ 时 $f(\boldsymbol{x}^{(t)}) - f(\boldsymbol{x}^{(l(t))}) \to 0$，矛盾。 ■

条件的作用可以逐条核对。去掉下有界，目标可以一直下降，例如 $f(x) = -x$，梯度恒为 -1。去掉 $\eta_1 > 0$ 的接受门槛，只要求 $\rho^{(t)} > 0$，下降量可以任意小，一般只能得到下极限的结论。去掉充分模型下降，候选步可以小到没有进展，比值 $\rho^{(t)}$ 即使接近 1 也无济于事。

二阶保证 定理 9.6只说明极限点是驻点，鞍点也是驻点。要排除负曲率，候选步必须真正使用负曲率。设 $\boldsymbol{B}^{(t)} = \boldsymbol{H}^{(t)}$，用下面的量衡量负曲率的大小：

$$\lambda_-^{(t)} = \max\{0,\ -\lambda_{\min}(\boldsymbol{H}^{(t)})\}.$$

要求存在常数 $c_2 > 0$，使得

$$\operatorname{pred}(\boldsymbol{p}^{(t)}) \geq c_2 \lambda_-^{(t)} (\Delta^{(t)})^2. \tag{9.28}$$

子问题的全局解满足这一条，$c_2 = 1/2$。取 $\boldsymbol{u}$ 是 $\lambda_{\min}$ 的单位特征向量，选符号使 $\langle \boldsymbol{g}, \boldsymbol{u}\rangle \leq 0$，点 $\Delta\boldsymbol{u}$ 可行，由它的模型值得

$$m(\boldsymbol{0}) - m(\Delta\boldsymbol{u}) = -\Delta\langle \boldsymbol{g}, \boldsymbol{u}\rangle - \frac{1}{2}\lambda_{\min}\Delta^2 \geq \frac{1}{2}\lambda_-\Delta^2,$$

全局解的预测下降不低于这个量。

Cauchy 步和截断共轭梯度不满足式 (9.28)。第 9.1节困难情形的数据 $\boldsymbol{g} = (0,1)^{\top}$，$\boldsymbol{B} = \operatorname{diag}(-1,3)$，$\Delta = 1$ 就是反例。截断共轭梯度第一步 $\boldsymbol{d}^{(0)} = (0,-1)^{\top}$，曲率为正，一步到 $(0,-1/3)^{\top}$，残差为零而停止，预测下降只有 $1/6$。全局解的预测下降是 $5/8$，并且沿 $\boldsymbol{e}_1$ 方向使用了负曲率。迭代只在 Krylov 子空间中进行，而这个子空间恰好与 $\boldsymbol{e}_1$ 正交，图 9.20(a) 画出了这一点。若 $\boldsymbol{g} = \boldsymbol{0}$，迭代第一步就停在 $\boldsymbol{p} = \boldsymbol{0}$，负曲率完全看不到。

定理 9.7　二阶下极限　在定理 9.5的条件之外，设 $\boldsymbol{B}^{(t)} = \boldsymbol{H}^{(t)}$，Hessian 是 L_H-Lipschitz 的，且候选步满足式 (9.28)。则

$$\liminf_{t\to\infty} \max\{\|\boldsymbol{g}^{(t)}\|_2,\ \lambda_{-}^{(t)}\} = 0. \tag{9.29}$$

证明　反设存在 $\varepsilon > 0$ 和 T_0，使得 $t \ge T_0$ 时

$$\max\{\|\boldsymbol{g}^{(t)}\|_2,\ \lambda_{-}^{(t)}\} \ge \varepsilon.$$

若 $\|\boldsymbol{g}^{(t)}\|_2 \ge \varepsilon$，定理 9.5证明的第二步依然适用。若 $\lambda_{-}^{(t)} \ge \varepsilon$，由 Hessian 的 Lipschitz 条件，模型误差不超过 $L_H\|\boldsymbol{p}\|_2^3/6$，再用式 (9.28)，

$$|1-\rho^{(t)}| \le \frac{L_H(\Delta^{(t)})^3/6}{c_2\varepsilon(\Delta^{(t)})^2} = \frac{L_H\Delta^{(t)}}{6c_2\varepsilon}.$$

所以取 $K_2 = \min\{K,\ 6c_2(1-\eta_2)/L_H\}$，$\Delta^{(t)} \le K_2\varepsilon$ 时半径不缩小，同样得到半径的正下界 $\Delta_{\min}$。每次接受至少下降

$$\eta_1 \min\Big\{c_1\varepsilon\min\{\Delta_{\min},\ \varepsilon/M\},\ c_2\varepsilon\Delta_{\min}^2\Big\} > 0,$$

与定理 9.5证明的第四步一样导出矛盾。 ∎

这个定理给出的是一个子列上的结论：若该子列有极限点 $\bar{\boldsymbol{x}}$，则 $\nabla f(\bar{\boldsymbol{x}}) = \boldsymbol{0}$ 且 $\nabla^2 f(\bar{\boldsymbol{x}}) \succeq \boldsymbol{0}$。这只是二阶必要条件，并不说明 $\bar{\boldsymbol{x}}$ 是局部极小点。图 9.20(b) 的 $f(x) = x^3$ 在 $x = 0$ 处梯度和 Hessian 都为零，从这一点出发，任何候选步都不能使模型下降，算法立即停止，而这个点不是局部极小点。

x^3 没有下界，这里只用它展示驻点附近的形状；把函数在远处改成有下界、导数 Lipschitz 的光滑函数，$x = 0$ 附近的情形不变。

所以不能仅凭采用信赖域就声称找到了局部极小点，更谈不上全局最优。一阶保证只需要充分模型下降，二阶保证要求候选步真正利用负曲率，两者对子问题的精度要求不同。这种差别在第 10章有进一步的讨论。

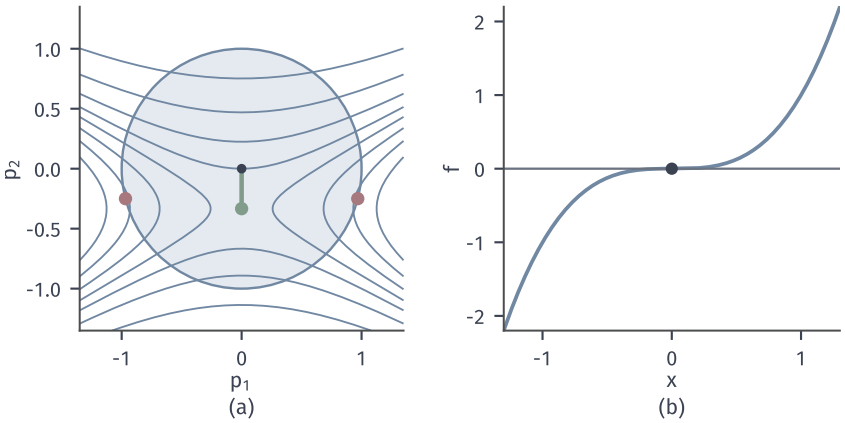


图 9.20　二阶保证的两个边界。(a) 模型 $\boldsymbol{g}=(0,1)^{\top}$，$\boldsymbol{B}=\mathrm{diag}(-1,3)$，$\Delta=1$：截断共轭梯度只沿 p_2 轴走到绿点，两个红点是全局解。(b) $f(x)=x^3$，黑点处梯度和 Hessian 都为零，满足二阶必要条件，却不是局部极小点。

迭代次数　定理 9.5的证明本身给出了复杂度。设前 T 轮都有 $\|\boldsymbol{g}^{(t)}\|_2\ge\varepsilon$，半径有下界 $\Delta_{\min}$，ε 小时 $\Delta_{\min}$ 与 ε 同阶。把第四步中每次接受的下降量代入总下降量 $f(\boldsymbol{x}^{(0)})-f_{\mathrm{low}}$，可知接受的轮数 A 满足

$$A\le\frac{f(\boldsymbol{x}^{(0)})-f_{\mathrm{low}}}{\eta_1 c_1\varepsilon\min\{\Delta_{\min},\,\varepsilon/M\}}=O(\varepsilon^{-2}). \tag{9.30}$$

拒绝的轮数 R 也受控制。半径每次接受至多乘以 2，每次拒绝乘以 θ，且始终不低于 $\Delta_{\min}$，所以 $\Delta^{(0)}2^{A}\theta^{R}\ge\Delta_{\min}$，由此得到

$$R\le\frac{A\ln 2+\ln(\Delta^{(0)}/\Delta_{\min})}{\ln(1/\theta)}. \tag{9.31}$$

因此外层总轮数是 $O(\varepsilon^{-2})$，只比接受轮数多一个常数倍和一个对数项。这个阶与梯度下降相同，并且对信赖域 Newton 法也是紧的，构造最坏的目标需要专门设计的例子，篇幅较长，读者可查阅专门的优化复杂度文献。这也提醒我们，信赖域 Newton 法在实践中的优势来自局部收敛和对曲率的利用，不来自这个最坏情形的上界。

局部收敛　设 $\boldsymbol{x}^{(t)}\to\boldsymbol{x}^{\star}$，$\nabla^2 f(\boldsymbol{x}^{\star})\succ\boldsymbol{0}$，Hessian 在 $\boldsymbol{x}^{\star}$ 附近 Lipschitz，并取 $\boldsymbol{B}^{(t)}=\boldsymbol{H}^{(t)}$。靠近解时 Newton 步趋于零，比值 $\rho^{(t)}$ 趋于 1，半径不再缩小，Newton 步终将落在球内。狗腿法、精确解都直接取 Newton 步，于是回到第 7章的局部二次收敛。截断共轭梯度由残差停止，$\eta\to 0$ 的快慢决定超线性或二次收敛，取 $\eta=\min\{0.1,\sqrt{\|\boldsymbol{g}\|_2}\}$ 时是超线性的。表 9.3中第 4 到第 7 轮就是这一阶段。这里只说明了机制，严格的证明还需要验证 $\rho^{(t)}\to 1$ 的速度，读者可查阅[1]。

[1] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

计算成本 评价信赖域的成本要把外层和内层分开算，表 9.4按一次子问题列出。

子问题解法	对 $\boldsymbol{B}$ 的要求	一次求解的代价
Cauchy 步	对称	1 次矩阵向量乘积
狗腿法	正定	1 次分解，约 $n^3/3$
截断共轭梯度	对称	j 次矩阵向量乘积，$j \le n$
精确解	对称	数次分解，约 $n^3/3$ 每次

表 9.4 一次子问题的代价，稠密矩阵，只计主要运算。

外层每一轮需要一次函数值 $f(\boldsymbol{x}^{(t)}+\boldsymbol{p}^{(t)})$；只有被接受的轮才需要新的梯度和 $\boldsymbol{B}$，拒绝的轮只多一次子问题和一次函数值。Hessian 向量乘积不必形成整个矩阵，用梯度差近似时，一次乘积大约是一次梯度的代价：

$$\boldsymbol{H}^{(t)}\boldsymbol{v} \approx \frac{\nabla f(\boldsymbol{x}^{(t)}+h\boldsymbol{v}) - \nabla f(\boldsymbol{x}^{(t)})}{h}. \tag{9.32}$$

所以比较方法时不能只看外层轮数，要把内层的乘积次数也算进去。拒绝也不是免费的：当函数值很贵时，半径初值和更新因子要避免频繁试探。

图 9.21是一个 $n=20$ 的实验，目标是

$$f(\boldsymbol{x}) = \sum_{i=1}^{19} \big[10(x_{i+1}-x_i^2)^2 + (1-x_i)^2\big].$$

三种方法的外层框架相同，参数同前。精确 Hessian 配截断共轭梯度用 26 个外层轮次、157 次 Hessian 向量乘积把梯度降到 10^{-7} 以下。SR1 模型从 $20\boldsymbol{I}$ 出发，用 90 轮，每轮要多算一次梯度，但完全不用 Hessian。只用 Cauchy 步时，1200 轮后梯度仍有 1.8×10^{-4}。三者都满足第 9.4节开头的假设，收敛定理对它们一视同仁，实际差距来自模型和子问题利用了多少曲率。

9.1 信赖域模型
9.2 子问题的求解
9.3 步的接受与半径更新
9.4 收敛与计算成本
9.5 本章小结

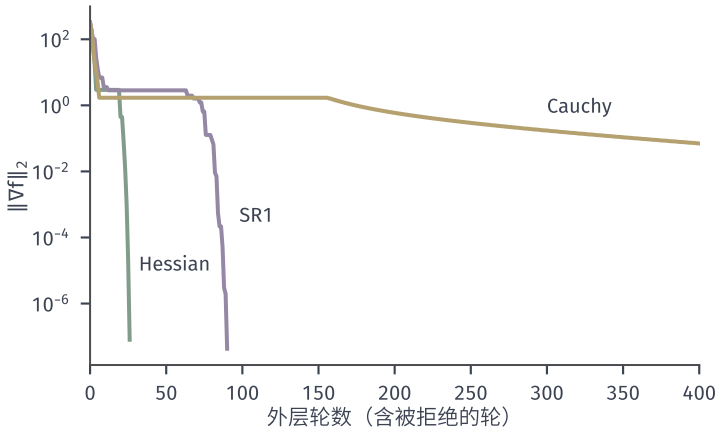


图 9.21 同一信赖域框架下三种选择的梯度范数（到当前轮为止的最小值，对数坐标）。绿线是 Hessian 配截断共轭梯度，紫线是 SR1 模型配截断共轭梯度，黄线是 Hessian 配 Cauchy 步。横轴的轮数包含被拒绝的轮。目标是正文中的 20 维函数，每个奇数位分量初值为 -1.2，其余为 1。

9.5 本章小结

本章开头的问题是：局部模型只在附近可靠，怎样同时决定往哪里走、走多远。信赖域的回答是把两件事合并成一个带半径约束的子问题，半径表示当前愿意相信模型的范围。这样即使曲率矩阵不定，子问题也有解，负曲率不必被修正掉，反而可以把步推向边界。

子问题的全局解由一个平移过的线性方程刻画，但外层迭代并不需要它。Cauchy 步给出充分模型下降的下限，狗腿法在 $\boldsymbol{B}$ 正定时用两段折线逼近解的轨迹，截断共轭梯度只用矩阵向量乘积，并用边界和曲率两条规则处理信赖域带来的新情况。

下降比 $\rho^{(t)}$ 把模型的预测和目标的实际下降作比较，决定接受这一步以及下一轮的半径。拒绝时点不动，模型沿用，只在更小的范围内重解。

收敛分析的条件和结论要分开记。目标下有界、梯度 Lipschitz、模型有界、充分模型下降，这四条保证梯度趋于零，外层轮数是 $O(\varepsilon^{-2})$，并不要求精确的 Hessian。取精确 Hessian 并要求候选步利用负曲率，才有二阶必要条件的保证，而这仍不等于找到局部极小点，更不等于全局最优。

表 9.5把三种子问题解法放在一起。

解法	$\boldsymbol{B}$ 的要求	主要代价	负曲率
Cauchy 步	对称	一次乘积	只看负梯度方向
狗腿法	正定	一次分解	不能处理
截断共轭梯度	对称	若干次乘积	遇到时走到边界
全局解	对称	数次分解	完整利用

表 9.5　子问题几种解法的对照。

最后一列是第 10章的入口。模型处理负曲率的能力只是工具，梯度很小时所得驻点属于哪一种，怎样可靠地离开鞍点，要在那里进一步明确。

10.1 驻点的类型
10.2 负曲率的检测
10.3 离开鞍点
10.4 停止条件与计算成本
10.5 本章小结

第 10 章

鞍点的处理

一个算法运行结束，报告梯度范数只有 0.06。这句话能说明什么？地面在这里几乎是平的，可是平的地方不止谷底，山顶和山口也是平的。下降算法走到山口附近，脚下坡度变得很小，步子随之变小，看起来像是快要到达终点，其实旁边还有一条向下的路。

非凸目标里，这种情形不是例外。第 6章到第 9章的保证，多数只说梯度趋于零。本章追问这以后的事：梯度已经很小时，怎样知道目标还能不能继续下降，怎样真正下降，最后又能声称得到了什么样的点。

全章用同一个二维目标把这些问题算到底。先把梯度为零的点分类，看清二阶信息能排除什么、还留下什么。然后讨论怎样只靠 Hessian 向量积找到向下弯曲的方向，并分清“找到”和“没有找到”分别能得出什么结论。

接着比较三种离开的办法：已知向下弯曲的方向时沿它走一步；只有梯度时给迭代点一点随机扰动；手里有二次模型时保留它的不定性。最后把停止条件和计算成本放在一起，说明一次运行究竟可以报告什么样的保证。

10.1 驻点的类型

梯度为零的点有哪几类，二阶信息能把它们分开到什么程度？先用一个具体的目标看清这些点的样子，再给定义，然后专门讨论二阶信息判断不了的情形。

贯穿全章的例子　我们用下面这个目标，它在 x_1 方向是一口双井，在 x_2 方向是一只碗：

$$f(\boldsymbol{x}) = \frac{1}{4}\left(x_1^2 - 1\right)^2 + \frac{1}{2}x_2^2. \tag{10.1}$$

它的梯度和 Hessian 可以直接写出：

$$\nabla f(\boldsymbol{x}) = \begin{bmatrix} x_1^3 - x_1 \\ x_2 \end{bmatrix}, \qquad \nabla^2 f(\boldsymbol{x}) = \begin{bmatrix} 3x_1^2 - 1 & 0 \\ 0 & 1 \end{bmatrix}. \tag{10.2}$$

令梯度为零，第二个分量给出 $x_2 = 0$，第一个分量给出 $x_1(x_1^2 - 1) = 0$。于是有三个驻点，它们的目标值和 Hessian 是

$$\begin{aligned} (\pm 1, 0): &\quad f = 0, \quad \nabla^2 f = \operatorname{diag}(2, 1), \\ (0, 0): &\quad f = \tfrac{1}{4}, \quad \nabla^2 f = \operatorname{diag}(-1, 1). \end{aligned}$$

$f \geq 0$ 处处成立，所以 $(\pm 1, 0)$ 是全局最优解。原点沿 x_2 方向是最低点，沿 x_1 方向是最高点，这正是一个山口。图 10.1画出了等高线和 $x_2 = 0$ 上的截面。

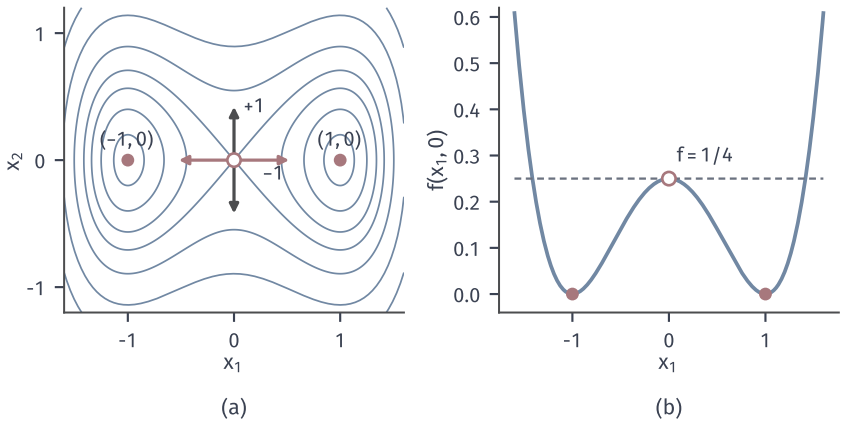


图 10.1 目标 (10.1)。(a) 蓝线是等高线，红点是两个全局最优解，空心点是原点处的鞍点，红色箭头是曲率为 -1 的方向，灰色箭头是曲率为 $+1$ 的方向。(b)$x_2 = 0$ 上的截面，鞍点位于两口井之间的高处，函数值为 $1/4$。

后面的分析要用到两个常数。Hessian (10.2)的元素随 x_1 增长，全局的常数不存在，所以我们只在带形区域上讨论：

$$\boldsymbol{U} = \{\boldsymbol{x} \in \mathbb{R}^2 : \ |x_1| \leq 1\}.$$

在 $\boldsymbol{U}$ 上，$3x_1^2 - 1$ 介于 -1 与 2 之间，因此谱范数 $\|\nabla^2 f\|_2 \leq 2$，光滑常数取 $L = 2$。Hessian 本身的变化由差值控制：

$$\left|(3x_1^2 - 1) - (3y_1^2 - 1)\right| = 3|x_1 + y_1|\,|x_1 - y_1| \leq 6|x_1 - y_1|.$$

所以在 $\boldsymbol{U}$ 上，Hessian 满足下面的 Lipschitz 条件，常数 $M = 6$：

$$\left\|\nabla^2 f(\boldsymbol{x}) - \nabla^2 f(\boldsymbol{y})\right\|_2 \leq M\|\boldsymbol{x} - \boldsymbol{y}\|_2.$$

全章固定步长取 $\alpha = 1/L = 1/2$。

三类驻点 站在驻点上，一阶变化消失了，目标的走势由 Hessian 决定。由 Taylor 公式，对小的 $\boldsymbol{h}$，

$$f(\boldsymbol{x}+\boldsymbol{h})-f(\boldsymbol{x})=\frac{1}{2}\boldsymbol{h}^{\top}\nabla^{2}f(\boldsymbol{x})\boldsymbol{h}+o\big(\|\boldsymbol{h}\|_{2}^{2}\big).$$

量 $\boldsymbol{h}^{\top}\nabla^{2}f(\boldsymbol{x})\boldsymbol{h}$ 的符号回答了“沿这个方向向上弯还是向下弯”。按照能否找到向下弯的方向，驻点分成下面几类。

定义 10.1 驻点的类型 设 f 二阶连续可微。若点 $\boldsymbol{x}$ 满足

$$\nabla f(\boldsymbol{x})=\boldsymbol{0}, \tag{10.3}$$

就称它为**一阶驻点**（first-order stationary point）。若还满足

$$\nabla^{2}f(\boldsymbol{x})\succeq\boldsymbol{0}, \tag{10.4}$$

就称它为**二阶驻点**（second-order stationary point）。若一阶驻点满足

$$\lambda_{\min}\big(\nabla^{2}f(\boldsymbol{x})\big)<0, \tag{10.5}$$

就称它为**严格鞍点**（strict saddle point）。

一阶驻点要么是二阶驻点，要么是严格鞍点，两者互斥。名称上有一点需要留意：局部极大点也满足式 (10.5)，在这个约定下同样算作严格鞍点。原因是算法只关心有没有向下弯的方向，而局部极大点和山口在这一点上没有区别。

二阶条件告诉我们这些类别和局部极小点的关系。第 1章证明过：局部极小点必须是二阶驻点；Hessian 正定的一阶驻点一定是严格局部极小点。因此严格鞍点一定不是局部极小点，而二阶驻点之中，Hessian 正定的部分一定是局部极小点。

表 10.1列出几个函数在原点的情形，它们的梯度在原点都为零。前两行是这两条结论直接判定的情形，后三行的 Hessian 半正定且奇异，正是二阶条件留下的缺口。

函数	原点的 Hessian	原点的类型
$x_1^2 + x_2^2$	$\mathrm{diag}(2, 2)$	严格局部极小点
$x_1^2 - x_2^2$	$\mathrm{diag}(2, -2)$	严格鞍点
$x_1^2 + x_2^4$	$\mathrm{diag}(2, 0)$	二阶驻点，局部极小点
$x_1^2 - x_2^4$	$\mathrm{diag}(2, 0)$	二阶驻点，不是局部极小点
$x_1^4 - x_2^4$	$\mathbf{0}$	二阶驻点，不是局部极小点

表 10.1 原点处的几种情形。第三行与第四行的梯度和 Hessian 完全相同，类型却不同。

退化情形 Hessian 半正定仍不足以说明是局部极小点。比较 $x_1^2 + x_2^4$ 和 $x_1^2 - x_2^4$：它们在原点的函数值、梯度和 Hessian 完全一样，差别只在四阶项。沿 x_2 轴看，

$$x_1^2 + x_2^4\big|_{x_1=0} = t^4, \qquad x_1^2 - x_2^4\big|_{x_1=0} = -t^4.$$

前者把原点托在最低处，后者从原点沿 x_2 轴一直下降。只看到二阶为止的信息，这两个函数无法分开。图 10.2用浅红色标出比原点函数值更低的区域，只要原点的任意小邻域内有浅红色，原点就不是局部极小点。

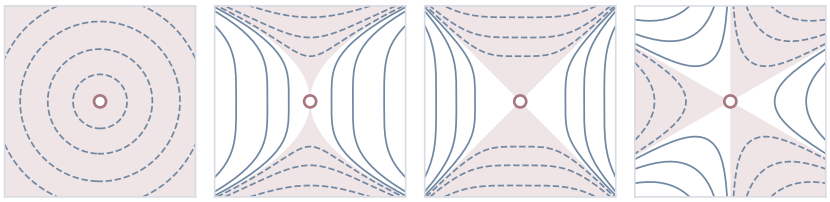


图 10.2 原点处四种不是局部极小点的驻点，蓝线是等高线，虚线为负值，浅红区域是函数值低于 $f(\mathbf{0}) = 0$ 的点。(a)$-x_1^2 - x_2^2$，局部极大点。(b)$x_1^2 - x_2^4$，Hessian 为 $\mathrm{diag}(2, 0)$。(c)$x_1^4 - x_2^4$，Hessian 为零。(d)$x_1^3 - 3x_1x_2^2$，Hessian 为零。后三个都没有负曲率，算法靠 Hessian 察觉不到下降方向。

图中 (a) 的负曲率是显式的，(b)、(c)、(d) 的下降则藏在更高阶的项里。(d) 沿 x_1 轴的函数值是 t^3，经过原点时由正变负，下降的一侧和上升的一侧挨在一起。

每条直线上都最低，仍然不是局部极小 有人会想：既然二阶信息只看直线方向，那么补上高阶项，逐条直线检查目标是否在原点取到局部最低，总该够了吧？下面的例子说明还是不够：

$$f(\boldsymbol{x}) = \big(x_2 - x_1^2\big)\big(x_2 - 2x_1^2\big). \tag{10.6}$$

展开得到 $x_2^2 - 3x_1^2x_2 + 2x_1^4$，所以原点是驻点，Hessian 是 $\mathrm{diag}(0, 2)$。先看经过原点的每条直线。沿 $x_2 = mx_1$，目标是

$$f(t, mt) = m^2t^2 - 3mt^3 + 2t^4.$$

$m \neq 0$ 时二次项为正，t 足够小时函数值为正。$m = 0$ 时是 $2t^4$，沿 x_2 轴是 x_2^2，也都大于零。所以原点在每条直线上都是严格局部最低点。

可是沿抛物线 $x_2 = \frac{3}{2}x_1^2$ 走，两个因子一正一负：

$$f\left(t, \tfrac{3}{2}t^2\right) = \left(\tfrac{1}{2}t^2\right)\left(-\tfrac{1}{2}t^2\right) = -\frac{1}{4}t^4 < 0.$$

原点的任意小邻域内都有比它更低的点，所以它不是局部极小点。图 10.3(a) 给出了几何解释：函数值为负的区域夹在两条抛物线之间，而任何一条直线在原点附近都会离开这个弯曲的窄缝。沿直线下降的想法，在这里看不到弯曲的下降路径。

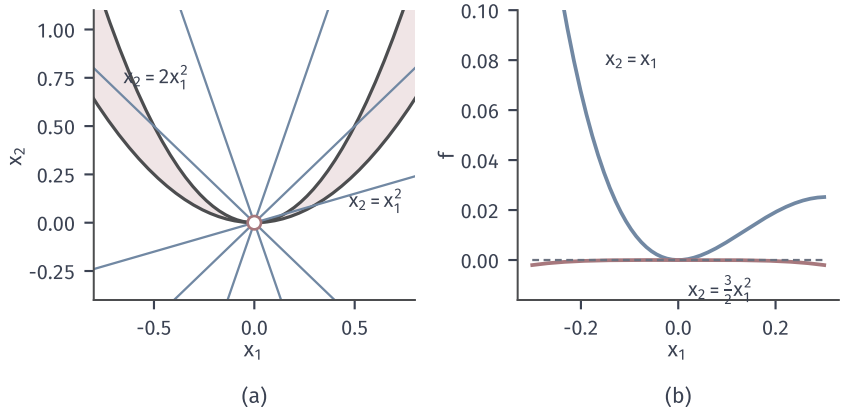


图 10.3　目标 (10.6)。(a) 浅红色是 $f < 0$ 的区域，夹在抛物线 $x_2 = x_1^2$ 和 $x_2 = 2x_1^2$ 之间；蓝色直线在原点附近都位于这个区域之外。(b) 沿直线 $x_2 = x_1$ 的函数值（蓝）在原点取最低，沿抛物线 $x_2 = \frac{3}{2}x_1^2$ 的函数值（红）为负。

二阶条件能排除什么　把这些类别按包含关系排列，得到图 10.4。每往里一层，条件就强一些。

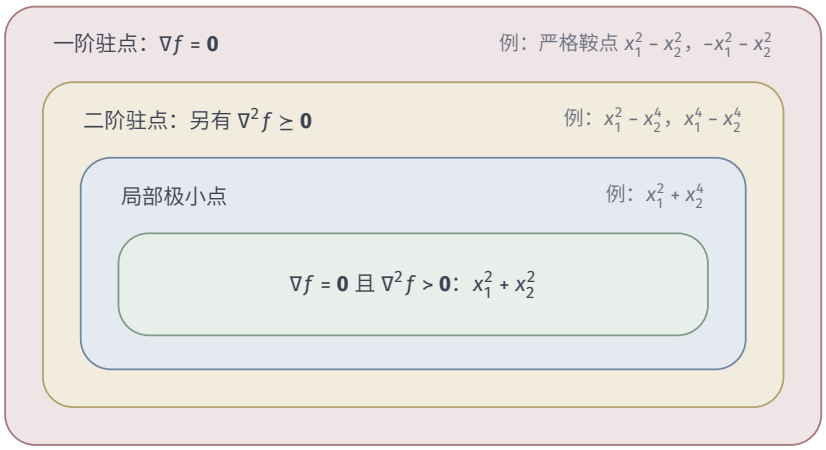


图 10.4　驻点类别的包含关系，每层右上角的函数在原点属于该层而不属于更内一层。最外层与第二层之间的差就是严格鞍点。第二层与第三层之间是退化的二阶驻点，二阶信息无法把它们和局部极小点分开。

由此可以说清楚二阶信息的能力。负特征值是确凿的证据：只要算出一个负的曲率，就能断定这里不是局部极小点。Hessian 正定也是确凿的证据：这里一定是严格局部极小点。两者之间的情形，二阶信息保持沉默，并不是“大概是极小点”的意思。

所以算法的目标要说得克制。排除严格鞍点是可以做到的事，这是后面几节的内容。判定一个退化的二阶驻点是否为局部极小点，一般需要更高阶的信息，本章的方法不处理。

局部条件不说明全局　上面的讨论还停留在局部。即使某点确实是局部极小点，也不说明它是全局最优解。看下面这个倾斜的双井：

$$\psi(x) = \frac{1}{4}x^4 + \frac{1}{3}x^3 - x^2, \qquad \psi'(x) = x(x-1)(x+2).$$

三个驻点的二阶导数由 $\psi''(x) = 3x^2 + 2x - 2$ 算出：

$$\psi''(0) = -2, \qquad \psi''(1) = 3, \qquad \psi''(-2) = 6.$$

$x = 1$ 是严格局部极小点，满足所有局部条件，函数值却是 $-5/12$，而全局最优解 $x = -2$ 的函数值是 $-8/3$。图 10.5中，从 $x = 1$ 到更低的井要先翻过 $x = 0$ 处的高坡。站在黄点上，任何只依赖当地导数的判据都看不到另一口井。

10.1 驻点的类型
10.2 负曲率的检测
10.3 离开鞍点
10.4 停止条件与计算成本
10.5 本章小结

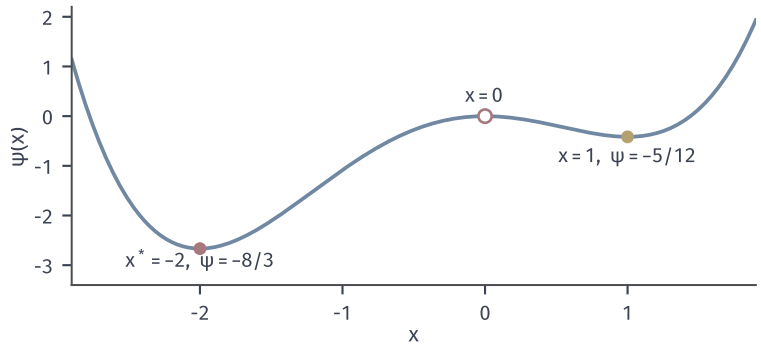


图 10.5 倾斜双井 $\psi(x) = x^4/4 + x^3/3 - x^2$。黄点 $x = 1$ 是严格局部极小点，红点 $x = -2$ 是全局最优解，空心点 $x = 0$ 是局部极大点。局部条件在黄点全部满足。

所以本章的“离开鞍点”只是把严格鞍点从可能的终点中排除。它既不判定退化的二阶驻点，也不保证到达全局最优解。

10.2 负曲率的检测

梯度已经很小时，怎样判断 Hessian 还有没有足够负的方向？变量很多时存不下 Hessian，所以我们特别关心只用 Hessian 向量积能走多远，以及找到方向和没找到方向分别说明了什么。

要找的是什么 对单位向量 $\boldsymbol{v}$，Rayleigh 商 $R(\boldsymbol{v}) = \boldsymbol{v}^{\top}\boldsymbol{H}\boldsymbol{v}$ 就是目标沿 $\boldsymbol{v}$ 的曲率。谱分解 $\boldsymbol{H} = \sum_i \lambda_i \boldsymbol{q}_i \boldsymbol{q}_i^{\top}$（特征值 $\lambda_1 \le \cdots \le \lambda_n$）给出

$$\min_{\|\boldsymbol{v}\|_2 = 1} R(\boldsymbol{v}) = \lambda_1 = \lambda_{\min}(\boldsymbol{H}), \tag{10.7}$$

最小值在 $\boldsymbol{q}_1$ 处取到。

我们并不需要真的求出 $\boldsymbol{q}_1$。只要有一个单位向量使 $R(\boldsymbol{v}) \le -\gamma$，其中 $\gamma > 0$，它就是负曲率方向，后面的下降分析用到的只是这个不等式。本章的 γ 始终表示负曲率的大小。

在原点，$\boldsymbol{H} = \operatorname{diag}(-1, 1)$，取 $\boldsymbol{v} = (\cos\theta, \sin\theta)$，Rayleigh 商是

$$R(\boldsymbol{v}) = -\cos^2\theta + \sin^2\theta = -\cos 2\theta.$$

夹角在 45° 以内的方向全都是负曲率方向，夹角在 30° 以内的方向满足 $R \le -1/2$。图 10.6显示负曲率方向占据一整个锥，这是检测能够用粗糙办法完成的原因。

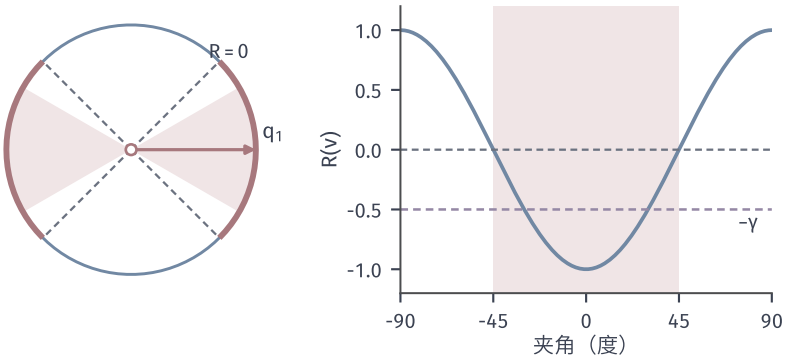


图 10.6 $\boldsymbol{H} = \mathrm{diag}(-1, 1)$ 的曲率随方向的变化。(a) 单位圆上的红色弧是 $R < 0$ 的方向，浅红扇形是 $R \le -1/2$ 的方向，$\boldsymbol{q}_1$ 是最小特征向量。(b)R 随方向与 $\boldsymbol{q}_1$ 夹角的变化，浅红带是负曲率的范围，紫色虚线是阈值 $-\gamma = -1/2$。

矩阵存得下时 n 不大时，可以直接计算 $\boldsymbol{H}$ 的特征分解，得到 $\lambda_{\min}$ 和 $\boldsymbol{q}_1$，运算量是 $O(n^3)$。如果只需要回答“$\lambda_{\min}$ 是否大于 $-\gamma$”，对 $\boldsymbol{H} + \gamma\boldsymbol{I}$ 作 Cholesky 分解更省：分解成功当且仅当 $\boldsymbol{H} + \gamma\boldsymbol{I}$ 正定，也就是 $\lambda_{\min} > -\gamma$。

例中在原点取 $\gamma = \frac{1}{2}$，要分解的矩阵是

$$\boldsymbol{H} + \gamma\boldsymbol{I} = \mathrm{diag}\left(-\tfrac{1}{2}, \tfrac{3}{2}\right).$$

第一个主元就是负的，分解失败，所以 $\lambda_{\min} \le -\frac{1}{2}$。这种方法没有舍入以外的误差，结论是确定的，代价是要存下并分解整个矩阵。

矩阵存不下时 第 7章介绍过 Hessian 向量积，一次乘积的成本与一次梯度同量级。用自动微分可以精确得到它，用差分则只需要两次梯度：

$$\hat{\boldsymbol{u}} = \frac{\nabla f(\boldsymbol{x} + h\boldsymbol{v}) - \nabla f(\boldsymbol{x})}{h}. \tag{10.8}$$

差分带来的误差要记入账。设 $\boldsymbol{v}$ 是单位向量，线段 $[\boldsymbol{x}, \boldsymbol{x} + h\boldsymbol{v}]$ 落在 Hessian 为 M-Lipschitz 的区域内。由微积分基本定理，

$$\nabla f(\boldsymbol{x} + h\boldsymbol{v}) - \nabla f(\boldsymbol{x}) - h\boldsymbol{H}\boldsymbol{v} = \int_0^h \left(\nabla^2 f(\boldsymbol{x} + s\boldsymbol{v}) - \nabla^2 f(\boldsymbol{x})\right)\boldsymbol{v}\,\mathrm{d}s.$$

被积函数的范数不超过 Ms，积分得 $Mh^2/2$。除以 h，得到

$$\|\hat{\boldsymbol{u}} - \boldsymbol{H}\boldsymbol{v}\|_2 \le \frac{Mh}{2}. \tag{10.9}$$

下面用数据验证。在点 $\boldsymbol{x} = \mathbf{0}$ 处取 $\boldsymbol{v} = (1,1)/\sqrt{2}$，$h = 0.1$，代入梯度 (10.2)，由 $\nabla f(\mathbf{0}) = \mathbf{0}$ 得到

$$\hat{\boldsymbol{u}} = \begin{bmatrix} h^2 v_1^3 - v_1 \\ v_2 \end{bmatrix} \approx \begin{bmatrix} -0.7036 \\ 0.7071 \end{bmatrix}, \qquad \boldsymbol{H}\boldsymbol{v} \approx \begin{bmatrix} -0.7071 \\ 0.7071 \end{bmatrix}.$$

实际误差约为 0.0035，界 (10.9)给出 0.3。原点左右对称，一阶误差项恰好抵消，这里的实际误差因此特别小。

图 10.7换到一般的点 $(0.3, 0.2)$。h 较大时误差与 h 成正比，h 太小时舍入误差占主导，这与第 7章的说法一致。

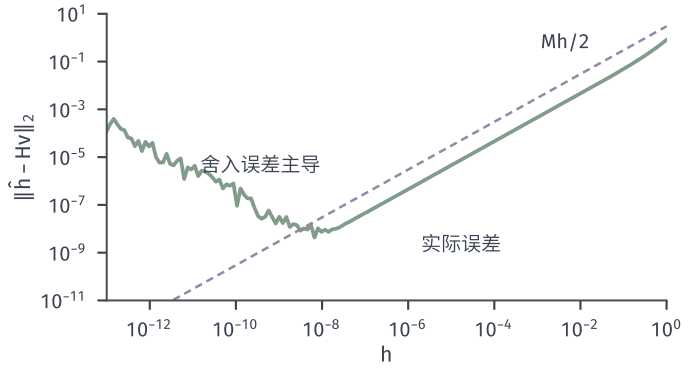


图 10.7　目标 (10.1)在点 $(0.3, 0.2)$ 沿 $(1,1)/\sqrt{2}$ 的差分 Hessian 向量积误差，绿线是实际误差（双精度计算），紫色虚线是上界 $Mh/2$，$M = 6$。h 小于约 10^{-8} 后舍入误差占主导。

主要思想：把最小特征值变成最大特征值　Hessian 向量积最直接的用法是幂迭代：反复乘一个矩阵，向量会转向模最大的特征值所对应的方向。可是我们要的是最小特征值，而 $\boldsymbol{H}$ 的最大模特征值可能是最大的正特征值。

解决办法是平移。设 $\|\boldsymbol{H}\|_2 \le L$，令

$$\boldsymbol{A} = L\boldsymbol{I} - \boldsymbol{H}. \tag{10.10}$$

$\boldsymbol{A}$ 的特征向量和 $\boldsymbol{H}$ 相同，特征值是 $a_i = L - \lambda_i \ge 0$，最大的 $a_1 = L - \lambda_{\min}$ 恰好对应 $\boldsymbol{H}$ 的最小特征值。于是对 $\boldsymbol{A}$ 作幂迭代：

$$\boldsymbol{v}^{(k+1)} = \frac{\boldsymbol{A}\boldsymbol{v}^{(k)}}{\|\boldsymbol{A}\boldsymbol{v}^{(k)}\|_2}, \qquad k = 0, 1, \ldots \tag{10.11}$$

每轮只用一次 Hessian 向量积。这里的上标 k 记检测内部的轮数，与外层的迭代 t 区分。把 $\boldsymbol{v}^{(0)}$ 按特征向量展开成 $\sum_i c_i \boldsymbol{q}_i$，$k$ 轮之后的方向正比于 $\sum_i c_i a_i^k \boldsymbol{q}_i$，与 a_1 相比较小的分量按几何级数衰减。

这个迭代还有另一层含义。除以 L 之后，$\boldsymbol{A}/L = \boldsymbol{I} - \frac{1}{L}\boldsymbol{H}$，这正是步长 $1/L$ 的梯度下降在二次目标上的迭代矩阵。所以幂迭代和鞍点附近的梯度下降是同一件事，第 10.3节还要用到这一点。

变量　在一个给定的点上运行检测，要维护的量是：

- $\boldsymbol{v}^{(k)} \in \mathbb{R}^n$：当前的单位向量；
- $\boldsymbol{u}^{(k)} \in \mathbb{R}^n$：Hessian 向量积 $\boldsymbol{H}\boldsymbol{v}^{(k)}$；
- $R^{(k)}$：Rayleigh 商 $\langle \boldsymbol{v}^{(k)}, \boldsymbol{u}^{(k)} \rangle$。

初始化　选定常数 $L \geq \|\boldsymbol{H}\|_2$，阈值 $\gamma > 0$，轮数上限 $k_{\max}$，并在单位球面上均匀随机地取 $\boldsymbol{v}^{(0)}$。例中在原点检测，$\boldsymbol{H} = \operatorname{diag}(-1, 1)$，$L = 2$，$\gamma = \frac{1}{2}$，设随机抽到

$$\boldsymbol{v}^{(0)} = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

每轮更新　第 k 轮依次执行以下步骤，满足结束条件时停止。

1. 计算 Hessian 向量积 $\boldsymbol{u}^{(k)} = \boldsymbol{H}\boldsymbol{v}^{(k)}$。例中第 0 轮得到

$$\boldsymbol{u}^{(0)} = \frac{1}{\sqrt{2}}\begin{bmatrix} -1 \\ 1 \end{bmatrix}.$$

2. 计算 $R^{(k)}$。若 $R^{(k)} \leq -\gamma$，返回 $\boldsymbol{v}^{(k)}$，宣布找到了负曲率方向；若 $k = k_{\max}$，宣布没有找到。例中第 0 轮 $R^{(0)} = 0 > -\frac{1}{2}$，继续。

3. 由式 (10.10)、(10.11)计算新方向，$\boldsymbol{A}\boldsymbol{v}^{(k)} = L\boldsymbol{v}^{(k)} - \boldsymbol{u}^{(k)}$ 不需要再乘一次 $\boldsymbol{H}$。例中第 0 轮

$$L\boldsymbol{v}^{(0)} - \boldsymbol{u}^{(0)} = \frac{1}{\sqrt{2}}\begin{bmatrix} 3 \\ 1 \end{bmatrix}, \qquad \boldsymbol{v}^{(1)} = \frac{1}{\sqrt{10}}\begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

第 1 轮计算得

$$\boldsymbol{u}^{(1)} = \frac{1}{\sqrt{10}}\begin{bmatrix} -3 \\ 1 \end{bmatrix}, \qquad R^{(1)} = \frac{-9 + 1}{10} = -0.8 \leq -\frac{1}{2}.$$

于是结束，最终得到 $\boldsymbol{v} = (3, 1)/\sqrt{10}$，它不是特征向量，曲率 -0.8 却已经达到要求，整个过程用了 2 次 Hessian 向量积。

起点为什么要随机 上面的计算依赖起点在 $\boldsymbol{q}_1$ 上有分量。若起点恰好是 $\boldsymbol{v}^{(0)} = (0, 1)$，第一个分量永远是零，迭代留在原地，Rayleigh 商永远是 $+1$，算法会错误地宣布没有负曲率。

起点在 $\boldsymbol{q}_1$ 上的分量小，要花的轮数就多。取 $\boldsymbol{v}^{(0)} = (s, \sqrt{1-s^2})$，$k$ 轮后两分量之比放大到 $3^k s/\sqrt{1-s^2}$，要让它达到 1 量级需要 $k \approx \log_3(1/s)$ 轮。图 10.8中曲线的拐点正随 s 变小而右移。这说明随机化换来的是“几乎不可能恰好落在坏的起点”，并且只需要付出对数代价。

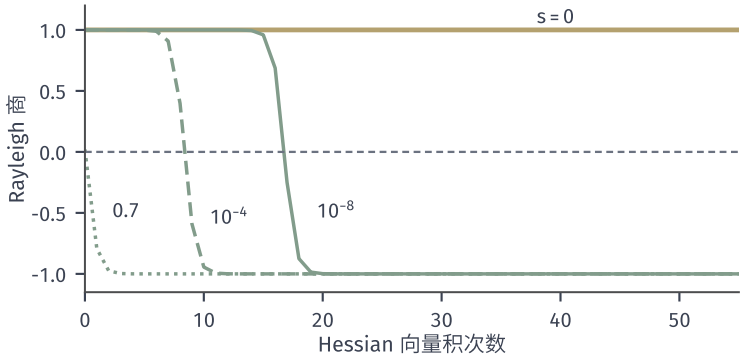


图 10.8 $\boldsymbol{H} = \mathrm{diag}(-1, 1)$，$L = 2$，幂迭代的 Rayleigh 商随乘积次数的变化，起点是 $(s, \sqrt{1-s^2})$。黄线 $s = 0$ 永远是 $+1$，绿线从左到右 $s = 0.7, 10^{-4}, 10^{-8}$，拐点依次右移，负曲率最终都被发现。

找到和没有找到，结论不一样 检测结束有两种结果，它们的可信程度差别很大。若 $R^{(k)} \le -\gamma$，这是一个算出来的事实：$\boldsymbol{v}$ 确实是曲率不超过 $-\gamma$ 的方向，与随机抽样的运气无关。

若没有找到，结论就只能是概率性的。$\boldsymbol{v}^{(0)}$ 可能运气很差，迭代还没转过来就结束了。下面的定理说明，轮数足够多时，这种情况发生的概率很小。图 10.9概括了两种结论的区别。

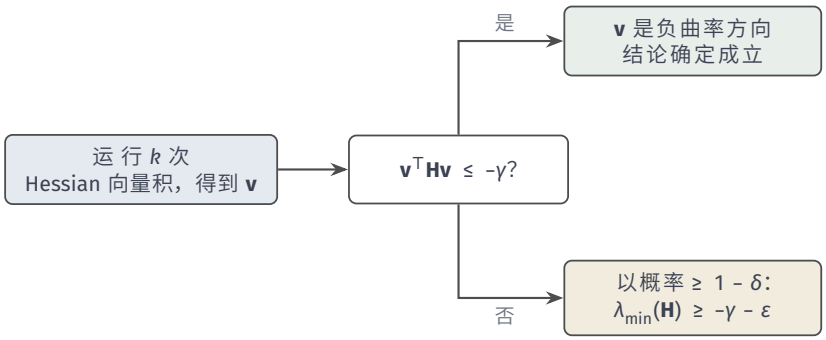


图 10.9 负曲率检测的两种结果。使用精确的 Hessian 向量积时，“找到”给出确定的结论；“未找到”只在随机起点成功的事件上成立，失败概率由 δ 控制，ε 是检测精度。

定理 10.2　幂迭代的概率保证　设 $\boldsymbol{H} \in \mathbb{R}^{n\times n}$ 对称，$\|\boldsymbol{H}\|_2 \le L$，$\varepsilon \in (0, L]$，$\delta \in (0,1)$。$\boldsymbol{v}^{(0)}$ 在单位球面上均匀分布，幂迭代 (10.11)运行 k 轮，其中

$$k \ge \frac{2L}{\varepsilon} \ln \frac{64Ln}{\pi \varepsilon \delta^3}. \tag{10.12}$$

则至少以 $1-\delta$ 的概率，

$$\boldsymbol{v}^{(k)\top} \boldsymbol{H} \boldsymbol{v}^{(k)} \le \lambda_{\min}(\boldsymbol{H}) + \varepsilon. \tag{10.13}$$

证明　证明分两步：先说明随机起点在 $\boldsymbol{q}_1$ 上的分量不会太小，再说明幂迭代把其余误差压下去。

第一步处理起点。球面上的均匀分布可以写成 $\boldsymbol{v}^{(0)} = \boldsymbol{z}/\|\boldsymbol{z}\|_2$，其中 $\boldsymbol{z}$ 是标准正态向量。由旋转不变性，可以设 $c_1 = z_1/\|\boldsymbol{z}\|_2$ 是 $\boldsymbol{v}^{(0)}$ 在 $\boldsymbol{q}_1$ 上的分量。标准正态密度不超过 $1/\sqrt{2\pi}$，所以

$$\mathbb{P}\big(|z_1| \le \tau\big) \le \tau \sqrt{\frac{2}{\pi}}.$$

取 $\tau = \frac{\delta}{2}\sqrt{\pi/2}$，这个概率不超过 $\delta/2$。又因为 $\mathbb{E}\|\boldsymbol{z}\|_2^2 = n$，由 Markov 不等式，

$$\mathbb{P}\Big(\|\boldsymbol{z}\|_2^2 > \frac{2n}{\delta}\Big) \le \frac{\delta}{2}.$$

因此至少以 $1-\delta$ 的概率，两个事件都不发生，此时

$$c_1^2 \ge \frac{\tau^2}{2n/\delta} = \frac{\pi\delta^3}{16n}.$$

第二步在这个事件上估计误差。记 $a_i = L - \lambda_i$，a_1 最大且 $0 \le a_i \le 2L$；若 $a_1 = 0$，$\boldsymbol{H} = L\boldsymbol{I}$，结论自动成立，下面设 $a_1 > 0$。$\boldsymbol{v}^{(k)}$ 正比于 $\boldsymbol{A}^k \boldsymbol{v}^{(0)}$，所以由 $\boldsymbol{v}^\top \boldsymbol{H} \boldsymbol{v} = L - \boldsymbol{v}^\top \boldsymbol{A} \boldsymbol{v}$，

$$\boldsymbol{v}^{(k)\top} \boldsymbol{H} \boldsymbol{v}^{(k)} - \lambda_{\min} = \frac{\sum_i c_i^2 a_i^{2k} (a_1 - a_i)}{\sum_i c_i^2 a_i^{2k}}.$$

把下标分成两组：$a_i \ge a_1 - \varepsilon/2$ 的一组，分子中的因子 $a_1 - a_i$ 不超过 $\varepsilon/2$，这一组对比值的贡献不超过 $\varepsilon/2$。

其余的下标满足 $a_i < a_1 - \varepsilon/2$，于是

$$a_i^{2k} \le a_1^{2k} \Big(1 - \frac{\varepsilon}{2a_1}\Big)^{2k} \le a_1^{2k} \exp\Big(-\frac{k\varepsilon}{a_1}\Big).$$

分母至少是 $c_1^2 a_1^{2k}$，$a_1 - a_i \le a_1 \le 2L$，$\sum_i c_i^2 = 1$，$a_1 \le 2L$ 使指数不小于 $k\varepsilon/(2L)$。所以这一组的贡献不超过

$$\frac{2L}{c_1^2}\exp\!\Big(-\frac{k\varepsilon}{2L}\Big).$$

代入 c_1^2 的下界和条件 (10.12)，这个量不超过 $\varepsilon/2$。两组相加，即得式 (10.13)。 ∎

定理中各个量的作用可以逐项核对。L/ε 来自幂迭代的收敛速度，要分辨相差 ε 的特征值，需要的轮数与 L/ε 成正比。$\ln n$ 和 $\ln(1/\delta)$ 只出现在对数里，它们是随机起点要付的代价。

结论的含义是：运行满轮数仍然没有发现 $R \le -\gamma$ 时，以至少 $1-\delta$ 的概率，

$$\lambda_{\min}(\boldsymbol{H}) \ge R^{(k)} - \varepsilon > -\gamma - \varepsilon. \tag{10.14}$$

例中取 $L = 2$，$n = 2$，$\varepsilon = \tfrac{1}{4}$，$\delta = 0.1$，式 (10.12)要求 $k \ge 204$。上面的手算只用 2 次乘积就找到了方向。两者不矛盾：定理针对的是任意 $\boldsymbol{H}$ 和最坏情形的起点分量，它要保证的是“没有找到”这个结论也能成立。

Lanczos 方法 幂迭代每轮只用最后一个向量，把前面的乘积结果都丢弃了。Lanczos 方法保留整个 Krylov 子空间

$$\mathcal{K}_k = \operatorname{span}\{\boldsymbol{v}^{(0)}, \boldsymbol{H}\boldsymbol{v}^{(0)}, \dots, \boldsymbol{H}^{k-1}\boldsymbol{v}^{(0)}\},$$

并在这个子空间上取 Rayleigh 商的最小值。乘积次数相同，幂迭代的结果也落在同一个子空间内，所以 Lanczos 给出的值不会更差。它的三项递推和实现细节可参考卷二第 15 章“Krylov 子空间法”，这里只用它的结果：标准正交基下 $\boldsymbol{H}$ 的投影是三对角矩阵 $\boldsymbol{T}_k$，$\boldsymbol{T}_k$ 的最小特征值就是这个子空间上的最小 Rayleigh 商。

下面用一个三阶矩阵比较两者，它是在例子的 Hessian 上补一个中间特征值得到的：

$$\boldsymbol{H} = \operatorname{diag}(-1, 1, 2), \qquad \boldsymbol{v}^{(0)} = \frac{1}{\sqrt{3}}(1,1,1)^{\top}.$$

第一步的对角元和残差是

$$\alpha_1 = \frac{2}{3}, \qquad \boldsymbol{w} = \boldsymbol{H}\boldsymbol{v}^{(0)} - \alpha_1 \boldsymbol{v}^{(0)} = \frac{1}{3\sqrt{3}}\begin{bmatrix} -5 \\ 1 \\ 4 \end{bmatrix}, \qquad \beta_1 = \|\boldsymbol{w}\|_2 = \frac{\sqrt{14}}{3}.$$

第二个基向量是 $\boldsymbol{w}/\beta_1$，由此计算第二个对角元，得到

$$\alpha_2 = \frac{-25 + 1 + 32}{42} = \frac{4}{21}, \qquad \boldsymbol{T}_2 = \begin{bmatrix} 2/3 & \sqrt{14}/3 \\ \sqrt{14}/3 & 4/21 \end{bmatrix}.$$

$\boldsymbol{T}_2$ 的最小特征值约为 -0.841。同样用 2 次乘积，$L = 2$ 的幂迭代 $\boldsymbol{v}^{(1)} \propto (3, 1, 0)$ 给出 -0.8。差距在小矩阵上不明显，在谱分布更不利时就很大了。

图 10.10是一个 $n = 400$ 的例子。第二小的特征值紧贴最小特征值时，幂迭代几乎停滞，Lanczos 仍然很快。原因是 k 次乘积相当于选一个 k 次多项式去放大 $\boldsymbol{q}_1$ 分量，幂迭代固定用 a^k，Lanczos 等于在所有 k 次多项式中选最好的一个。

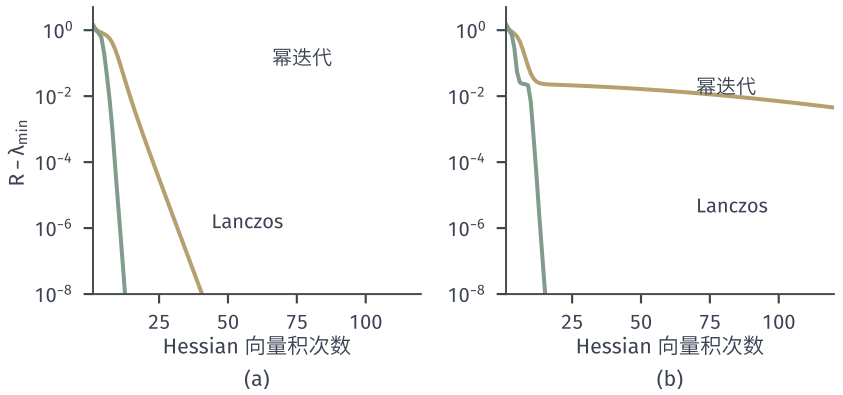


图 10.10　同一个随机起点下幂迭代（黄，$L = 2$）与 Lanczos 方法（绿）的 Rayleigh 商误差，$n = 400$，$\lambda_{\min} = -0.2$，其余特征值在 $[0.5, 2]$ 上均匀取样，只有第二小的特征值另行指定。(a) 第二小特征值为 0.3。(b) 第二小特征值为 -0.17，与最小特征值很接近。

定量结果是：均匀随机起点的 Lanczos 方法运行约 $\sqrt{L/\varepsilon}\,\ln(n/\delta^2)$ 次乘积，就以至少 $1 - \delta$ 的概率达到精度 ε。与定理 10.2相比，L/ε 换成了它的平方根。证明需要用到 Chebyshev 多项式在区间外的增长估计，篇幅较长，读者可查阅数值线性代数的专门著作，这里只把它作为不加证明的事实使用。

Lanczos 的计算也有代价：要存基向量才能算出方向，三项递推在有限精度下会失去正交性，运行次数多时需要重新正交化或重启。

误差怎样记入　前面的结论默认 Hessian 向量积是精确的，用差分时要补上式 (10.9)。对“找到”这一方，算出的 $\hat{R} = \boldsymbol{v}^{\top}\hat{\boldsymbol{u}}$ 与真实 Rayleigh 商至多相差 $Mh/2$，把判定条件改成 $\hat{R} \le -\gamma - Mh/2$，就能确定地推出 $R(\boldsymbol{v}) \le -\gamma$。

10.1 驻点的类型
10.2 负曲率的检测
10.3 离开鞍点
10.3.1 负曲率步
10.3.2 扰动梯度法
10.3.3 利用非正定模型
10.4 停止条件与计算成本
10.5 本章小结

对“没有找到”这一方，差分误差还会改变迭代本身，定理 10.2不能直接套用，分析时必须把每一轮的乘积误差累加进去。实际程序里，要做这一判断时通常用自动微分得到精确的乘积。表 10.2总结了几种方式。

检测方式	成本	找到时	未找到时
特征分解	$O(n^3)$	确定	确定
Cholesky 试探	$O(n^3)$，只判断	确定	确定
幂迭代	$O(\frac{L}{\varepsilon}\ln\frac{n}{\delta})$ 次乘积	确定	$\geq 1-\delta$
Lanczos	$O(\sqrt{\frac{L}{\varepsilon}}\ln\frac{n}{\delta})$ 次乘积	确定	$\geq 1-\delta$
差分乘积	每次两个梯度	加余量 $Mh/2$	累加误差

表 10.2　负曲率检测方式的比较，“确定”不计舍入误差，“$\geq 1-\delta$”指结论成立的概率。$O(\cdot)$ 中省略了 L/ε 的对数因子。

10.3 离开鞍点

迭代点已经到了梯度很小的鞍点邻域，怎样离开？回答取决于手里有什么信息。知道一个负曲率方向时，可以沿它走一步；只有梯度时，可以给迭代点一点随机扰动，让梯度下降自己放大不稳定的分量；有二次模型时，可以保留模型的不定性，让子问题自己走到负曲率的一侧。三种机制各有条件，都不能把严格鞍点的结论直接搬到退化驻点上。

10.3.1 负曲率步

上一节的检测给出了单位向量 $\boldsymbol{v}$，满足 $\boldsymbol{v}^{\top}\boldsymbol{H}\boldsymbol{v}\leq -\gamma$。站在山口上，这是一条明确的下坡路。问题是这样走一步能保证下降多少，步长又该取多大。

为什么要控制 Hessian 的变化　二阶模型沿 $\boldsymbol{v}$ 的预测是 $-\frac{1}{2}\gamma\alpha^2$，步长越大下降越多，但这个预测不可能一直成立。模型只在局部有效，走远了 Hessian 会变。例中沿 x_1 轴，

$$f(\alpha,0)=\frac{1}{4}\bigl(\alpha^2-1\bigr)^2.$$

$\alpha=1$ 处到达谷底，$\alpha=\sqrt{2}$ 处函数值回到 $1/4$，再往前目标反而高于起点。所以负曲率方向不能无限延长，步长要受 Hessian 变化速度的约束，这个速度就是 M。下面的引理给出二阶模型的误差。

引理 10.3　三次上界　设 $\nabla^2 f$ 在凸集 $\boldsymbol{U}$ 上是 M-Lipschitz 的，$\boldsymbol{x}$ 与 $\boldsymbol{x}+\boldsymbol{p}$ 都在 $\boldsymbol{U}$ 中。记 $\boldsymbol{g}=\nabla f(\boldsymbol{x})$，$\boldsymbol{H}=\nabla^2 f(\boldsymbol{x})$，则

$$\left| f(\boldsymbol{x}+\boldsymbol{p}) - f(\boldsymbol{x}) - \langle \boldsymbol{g}, \boldsymbol{p}\rangle - \frac{1}{2}\boldsymbol{p}^{\top}\boldsymbol{H}\boldsymbol{p} \right| \le \frac{M}{6}\|\boldsymbol{p}\|_2^3. \tag{10.15}$$

证明　令 $\phi(s)=f(\boldsymbol{x}+s\boldsymbol{p})$，$s\in[0,1]$。由积分余项形式的 Taylor 公式，

$$\phi(1)=\phi(0)+\phi'(0)+\int_0^1 (1-s)\phi''(s)\,\mathrm{d}s.$$

其中 $\phi'(0)=\langle \boldsymbol{g},\boldsymbol{p}\rangle$。又因为 $\int_0^1(1-s)\,\mathrm{d}s=\frac{1}{2}$，二次项可以写进同一个积分，得到

$$f(\boldsymbol{x}+\boldsymbol{p}) - f(\boldsymbol{x}) - \langle \boldsymbol{g},\boldsymbol{p}\rangle - \frac{1}{2}\boldsymbol{p}^{\top}\boldsymbol{H}\boldsymbol{p} = \int_0^1 (1-s)\big(\phi''(s)-\phi''(0)\big)\,\mathrm{d}s.$$

ϕ 的二阶导数是 Hessian 沿 $\boldsymbol{p}$ 的二次型，由 Lipschitz 条件，

$$|\phi''(s)-\phi''(0)| = \left|\boldsymbol{p}^{\top}\big(\nabla^2 f(\boldsymbol{x}+s\boldsymbol{p})-\boldsymbol{H}\big)\boldsymbol{p}\right| \le Ms\|\boldsymbol{p}\|_2^3.$$

代入并用 $\int_0^1(1-s)s\,\mathrm{d}s=\frac{1}{6}$，即得式 (10.15)。 ■

选符号，定步长　梯度不为零时，$\boldsymbol{v}$ 和 $-\boldsymbol{v}$ 的曲率相同，一阶项却相反。所以先选符号，使一阶项不起反作用。下面的定理给出一步的下降量。

定理 10.4　负曲率步的下降　设单位向量 $\boldsymbol{v}$ 满足 $\boldsymbol{v}^{\top}\boldsymbol{H}\boldsymbol{v}\le -\gamma<0$ 和 $\langle \boldsymbol{g},\boldsymbol{v}\rangle\le 0$，引理 10.3的条件对 $\boldsymbol{p}=\alpha\boldsymbol{v}$ 成立。则对 $\alpha>0$，

$$f(\boldsymbol{x}+\alpha\boldsymbol{v}) \le f(\boldsymbol{x}) - \frac{\gamma}{2}\alpha^2 + \frac{M}{6}\alpha^3. \tag{10.16}$$

取 $\alpha=2\gamma/M$ 时，

$$f(\boldsymbol{x}+\alpha\boldsymbol{v}) \le f(\boldsymbol{x}) - \frac{2\gamma^3}{3M^2}. \tag{10.17}$$

证明　由式 (10.15)取 $\boldsymbol{p}=\alpha\boldsymbol{v}$，$\|\boldsymbol{p}\|_2=\alpha$，得到

$$f(\boldsymbol{x}+\alpha\boldsymbol{v}) \le f(\boldsymbol{x}) + \alpha\langle \boldsymbol{g},\boldsymbol{v}\rangle + \frac{\alpha^2}{2}\boldsymbol{v}^{\top}\boldsymbol{H}\boldsymbol{v} + \frac{M}{6}\alpha^3.$$

由 $\langle \boldsymbol{g}, \boldsymbol{v} \rangle \le 0$ 和 $\boldsymbol{v}^{\top}\boldsymbol{H}\boldsymbol{v} \le -\gamma$，即得式 (10.16)。右端作为 α 的函数，对 α 求导得 $-\gamma\alpha + \tfrac{1}{2}M\alpha^2$，在 $\alpha = 2\gamma/M$ 处取到最小。代入得

$$-\frac{\gamma}{2}\cdot\frac{4\gamma^2}{M^2} + \frac{M}{6}\cdot\frac{8\gamma^3}{M^3} = -\frac{2\gamma^3}{M^2} + \frac{4\gamma^3}{3M^2} = -\frac{2\gamma^3}{3M^2}.$$

■

下降量只依赖负曲率的大小和 Hessian 的变化速度，与梯度多小无关。这正是它补上梯度步短板的地方：梯度步的保证是 $\|\boldsymbol{g}\|_2^2/(2L)$，鞍点附近这个量几乎为零。

例中在原点取 $\boldsymbol{v} = (1, 0)$，$\gamma = 1$，$M = 6$，步长 $\alpha = 1/3$。定理保证的下降是

$$\frac{2\gamma^3}{3M^2} = \frac{1}{54} \approx 0.0185.$$

实际下降是

$$f(\mathbf{0}) - f\big(\tfrac{1}{3}, 0\big) = \frac{1}{4} - \frac{16}{81} \approx 0.0525.$$

图 10.11(a) 沿 x_1 轴比较目标（蓝）、二次模型（绿）和三次上界（紫）。三次上界在 $\boldsymbol{U}$ 内从上方盖住目标，绿点 $\alpha = 1/3$ 是上界的最低点，这个步长比实际的最好步长 $\alpha = 1$ 保守得多。

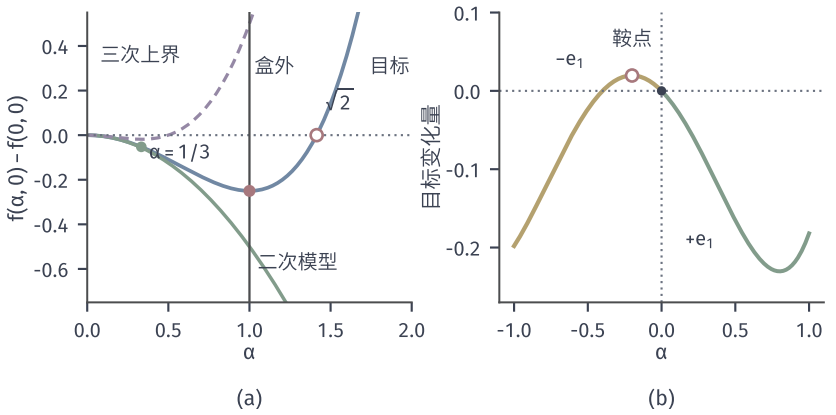


图 10.11　沿负曲率方向的一维截面。(a) 原点沿 $\boldsymbol{e}_1$：蓝线是目标减去 $f(\mathbf{0})$，绿线是二次模型 $-\alpha^2/2$，紫色虚线是三次上界 $-\alpha^2/2 + \alpha^3$，竖线是带形 $\boldsymbol{U}$ 的边界。空心点 $\alpha = \sqrt{2}$ 处目标回到起点的值。(b) 从 $(0.2, 0)$ 出发沿 $\pm\boldsymbol{e}_1$ 的目标变化，此处 $\langle \boldsymbol{g}, \boldsymbol{e}_1 \rangle < 0$。绿线一开始就下降，黄线先升到鞍点的高度才下降。

符号的作用见图 10.11(b)。在 $(0.2, 0)$ 处，梯度的第一个分量是 $0.008 - 0.2 = -0.192$，$+\boldsymbol{e}_1$ 满足 $\langle \boldsymbol{g}, \boldsymbol{v} \rangle < 0$。朝 $-\boldsymbol{e}_1$ 走，目标要先爬回鞍点才开始下降，一阶项抵消了曲率的好处。

不知道 M 时　步长 $2\gamma/M$ 要用到 M，多数问题不知道它的值。这时可以回溯：从 α_0 开始，不断折半，直到满足

$$f(\boldsymbol{x}+\alpha\boldsymbol{v}) \le f(\boldsymbol{x}) - \frac{\gamma}{4}\alpha^2. \tag{10.18}$$

由式 (10.16)，条件成立只需要

$$-\frac{1}{2}\gamma\alpha^2 + \frac{1}{6}M\alpha^3 \le -\frac{1}{4}\gamma\alpha^2,$$

也就是 $\alpha \le 3\gamma/(2M)$。折半回溯接受的步长因此不小于 $\min\{\alpha_0, 3\gamma/(4M)\}$，当 α_0 足够大时，一步的下降不少于

$$\frac{\gamma}{4}\Big(\frac{3\gamma}{4M}\Big)^2 = \frac{9\gamma^3}{64M^2}.$$

例中取 $\alpha_0 = 2$，$f(2,0) = 9/4$ 被拒绝，$\alpha = 1$ 时 $f(1,0) = 0 \le \frac{1}{4} - \frac{1}{4}$，被接受，一步到达谷底。

主要思想：梯度步和负曲率步交替　梯度步在梯度大时有效，负曲率步在梯度小时仍然有效，两者正好互补。算法每轮先看梯度：梯度大就走梯度步；梯度小才花力气检测负曲率；两者都不能下降就停止。写成公式，

$$\boldsymbol{x}^{(t+1)} = \begin{cases} \boldsymbol{x}^{(t)} - \dfrac{1}{L}\boldsymbol{g}^{(t)}, & \|\boldsymbol{g}^{(t)}\|_2 > \varepsilon_g, \\ \boldsymbol{x}^{(t)} + \dfrac{2\gamma^{(t)}}{M}\boldsymbol{v}^{(t)}, & \text{其他情形且检测到负曲率.} \end{cases} \tag{10.19}$$

其中单位向量 $\boldsymbol{v}^{(t)}$ 的曲率是 $-\gamma^{(t)}$，符号已经选定。ε_g 和 ε_H 是梯度和曲率的容差，第 10.4节再讨论怎样取值。

变量　算法要维护的量是：

- $\boldsymbol{x}^{(t)} \in \mathbb{R}^n$：当前点；
- $\boldsymbol{g}^{(t)} \in \mathbb{R}^n$：当前梯度，每轮读取一次；
- $\boldsymbol{v}^{(t)} \in \mathbb{R}^n$，$\gamma^{(t)} > 0$：只在梯度小的轮次计算的负曲率方向及其大小。

初始化　选定 $\boldsymbol{x}^{(0)}$、L、M 和容差。例中 $L = 2$，$M = 6$，$\varepsilon_g = 0.1$，$\varepsilon_H = \sqrt{M\varepsilon_g} \approx 0.775$，起点取在 x_2 轴上，并且用特征分解做检测：

$$\boldsymbol{x}^{(0)} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

每轮更新　第 t 轮依次执行以下步骤，直到第 3 步宣布停止。

1. 计算 $\boldsymbol{g}^{(t)}$。若 $\|\boldsymbol{g}^{(t)}\|_2 > \varepsilon_g$，由式 (10.19)走梯度步，进入下一轮。例中前 4 轮 x_1 一直是 0，x_2 每轮减半：

$$\boldsymbol{x}^{(1)} = \begin{bmatrix} 0 \\ 0.5 \end{bmatrix}, \quad \boldsymbol{x}^{(2)} = \begin{bmatrix} 0 \\ 0.25 \end{bmatrix}, \quad \boldsymbol{x}^{(3)} = \begin{bmatrix} 0 \\ 0.125 \end{bmatrix}, \quad \boldsymbol{x}^{(4)} = \begin{bmatrix} 0 \\ 0.0625 \end{bmatrix}.$$

2. 否则检测负曲率。例中第 4 轮 $\|\boldsymbol{g}^{(4)}\|_2 = 0.0625 \le 0.1$，由式 (10.2)，

$$\boldsymbol{H}^{(4)} = \operatorname{diag}(-1, 1), \qquad \lambda_{\min} = -1 < -\varepsilon_H.$$

3. 若 $\lambda_{\min} \ge -\varepsilon_H$，停止并返回 $\boldsymbol{x}^{(t)}$。否则取 $\boldsymbol{v}^{(t)}$ 为最小特征向量，$\gamma^{(t)} = -\lambda_{\min}$，选好符号，由式 (10.19)走负曲率步。例中第 4 轮 $\langle \boldsymbol{g}^{(4)}, \boldsymbol{e}_1 \rangle = 0$，取 $\boldsymbol{v} = \boldsymbol{e}_1$，步长 $1/3$，得到

$$\boldsymbol{x}^{(5)} = \begin{bmatrix} 1/3 \\ 0.0625 \end{bmatrix}.$$

此后梯度已经变大，算法回到梯度步。表 10.3列出全过程。第 9 轮 $\|\boldsymbol{g}^{(9)}\|_2 = 0.060 \le 0.1$，Hessian 是 $\operatorname{diag}(1.815, 1)$，$\lambda_{\min} = 1 \ge -\varepsilon_H$，算法停止，最终得到 $\boldsymbol{x}^{(9)} \approx (0.9686, 0.0039)$。

t	$\boldsymbol{x}^{(t)}$	f	$\|\boldsymbol{g}^{(t)}\|_2$	$\lambda_{\min}$	本轮动作
0	(0, 1)	0.7500	1.000	−1	梯度步
1	(0, 0.5)	0.3750	0.500	−1	梯度步
2	(0, 0.25)	0.2813	0.250	−1	梯度步
3	(0, 0.125)	0.2578	0.125	−1	梯度步
4	(0, 0.0625)	0.2520	0.063	−1	负曲率步
5	(0.3333, 0.0625)	0.1995	0.303	−0.667	梯度步
6	(0.4815, 0.0313)	0.1480	0.371	−0.305	梯度步
7	(0.6664, 0.0156)	0.0774	0.371	0.332	梯度步
8	(0.8516, 0.0078)	0.0189	0.234	1	梯度步
9	(0.9686, 0.0039)	0.0010	0.060	1	停止

表 10.3　梯度步与负曲率步在目标 (10.1)上的运行。$\varepsilon_g = 0.1$，$\varepsilon_H \approx 0.775$，$\lambda_{\min}$ 是 Hessian (10.2)的最小特征值，第 8、9 轮第一个对角元已大于 1，最小特征值取到 1。

图 10.12对照了不做检测的梯度下降。两者前 4 轮完全相同；梯度下降从此沿 x_2 轴收敛到鞍点，目标停在 $1/4$，而负曲率步使迭代点离开了这条轴。

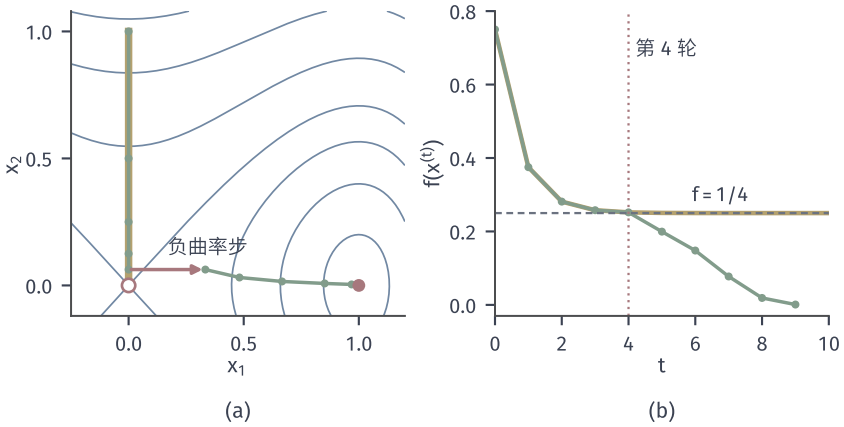


图 10.12 从 $(0,1)$ 出发的运行，步长 $\alpha = 1/2$。(a) 绿色折线是梯度步与负曲率步的路径，红色箭头是第 4 轮的负曲率步，黄线（被绿线部分遮挡）是梯度下降，沿 x_2 轴收敛到空心点所示的鞍点。(b) 目标值随轮数的变化，黄线趋于虚线 $f = 1/4$，绿线在红色点线所示的第 4 轮之后继续下降。

算法分析 每轮的下降都有下界，累加就得到轮数上界，论证与第 5章的累加下降相同。下面的定理把检测精度写成一个参数，以便同时覆盖精确和近似检测。

定理 10.5 交替算法的轮数 设 f 有下界 $f_{\inf}$，∇f 和 $\nabla^2 f$ 在包含各步线段的凸集上分别是 L-Lipschitz 和 M-Lipschitz 的。设每次走负曲率步时都有 $\gamma^{(t)} \ge \gamma_0 > 0$，记 $\Delta_f = f(\boldsymbol{x}^{(0)}) - f_{\inf}$。则算法 (10.19)停止之前的轮数 T 满足

$$T \le \Delta_f \max\left\{\frac{2L}{\varepsilon_g^2},\ \frac{3M^2}{2\gamma_0^3}\right\}. \tag{10.20}$$

证明 由下降引理，走梯度步的轮次下降至少 $\|\boldsymbol{g}^{(t)}\|_2^2/(2L)$，而这些轮次 $\|\boldsymbol{g}^{(t)}\|_2 > \varepsilon_g$，下降超过 $\varepsilon_g^2/(2L)$。

由定理 10.4，走负曲率步的轮次下降至少 $2\gamma_0^3/(3M^2)$。记两者中较小的为 c，累加 T 轮得

$$\Delta_f \ge f(\boldsymbol{x}^{(0)}) - f(\boldsymbol{x}^{(T)}) \ge Tc.$$

除以 c 即得式 (10.20)。 ■

例中 $\Delta_f = 3/4$。精确检测对应 $\gamma_0 = \varepsilon_H$，两项分别是 400 和约 116，上界是 300 轮，实际只用了 9 轮。这也是一个最坏情形的界，它只用到 L、M、Δ_f，没有用到例子的具体形状。

10.1 驻点的类型
10.2 负曲率的检测
10.3 离开鞍点
10.3.1 负曲率步
10.3.2 扰动梯度法
10.3.3 利用非正定模型
10.4 停止条件与计算成本
10.5 本章小结

适用范围 这个算法要求能算出负曲率方向，在第 10.2节的意义下，检测是确定的或者带失败概率的，第 10.4节再把这部分成本计入。定理只保证算法在有限步内停止，停时的点满足两个容差，它不说明这个点是局部极小点。Hessian 不是 Lipschitz 连续时，式 (10.15)没有依据，步长公式也就失去了基础。

10.3.2 扰动梯度法

现在假设只能读取梯度，连 Hessian 向量积也不用。梯度下降在鞍点附近究竟怎样运动，是分析的起点。

鞍点附近的线性运动 设 $\boldsymbol{x}^\star$ 是严格鞍点，$\boldsymbol{H} = \nabla^2 f(\boldsymbol{x}^\star)$。在 $\boldsymbol{x}^\star$ 附近 $\nabla f(\boldsymbol{x}) \approx \boldsymbol{H}(\boldsymbol{x} - \boldsymbol{x}^\star)$，梯度下降近似于线性迭代：

$$\boldsymbol{x}^{(t+1)} - \boldsymbol{x}^\star \approx (\boldsymbol{I} - \alpha \boldsymbol{H})\big(\boldsymbol{x}^{(t)} - \boldsymbol{x}^\star\big). \tag{10.21}$$

沿特征向量 $\boldsymbol{q}_i$ 的分量每步乘以 $1 - \alpha\lambda_i$。$\alpha = 1/L$ 时，正曲率方向的因子在 $[0, 1)$ 内，分量收缩；负曲率方向的因子 $1 + \alpha|\lambda_i|$ 大于 1，分量放大。这正是第 10.2节的幂迭代：梯度下降本身就在放大最负的方向。

例中两个坐标的迭代是

$$x_1^{(t+1)} = \frac{3}{2} x_1^{(t)} - \frac{1}{2}\big(x_1^{(t)}\big)^3, \qquad x_2^{(t+1)} = \frac{1}{2} x_2^{(t)}.$$

在原点附近，x_1 每步约乘以 1.5，x_2 每步乘以 0.5。图 10.13(b) 的对数坐标下，两者都是直线，直到 x_1 接近 1 才不再增长。

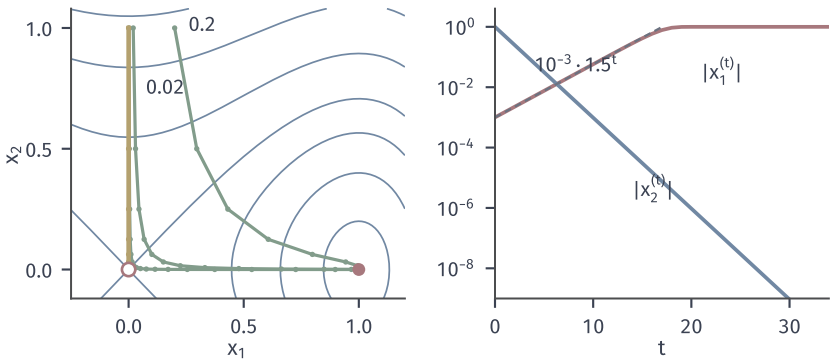


图 10.13 目标 (10.1)上步长 1/2 的梯度下降。(a) 从 $(s, 1)$ 出发的路径，绿线 $s = 0.2, 0.02, 0.002$，黄线 $s = 0$ 沿 x_2 轴收敛到鞍点。s 越小，路径越贴近鞍点，徘徊越久。(b) 从 $(10^{-3}, 1)$ 出发，$|x_1^{(t)}|$（红）按 1.5^t 增长（灰色虚线），$|x_2^{(t)}|$（蓝）按 0.5^t 衰减。

什么样的初值会收敛到鞍点 例中只要 $x_1^{(0)} \neq 0$，这个分量迟早被放大；只有 $x_1^{(0)} = 0$ 的点才一直留在 x_2 轴上，收敛到鞍点。这条轴是鞍点的**稳定流形**（stable manifold），二维平面上它的面积为零。

这个观察有严格的版本：设 f 二阶连续可微，∇f 全局 L-Lipschitz，步长 $0 < \alpha < 1/L$，初值的分布对 Lebesgue 测度绝对连续，则梯度下降收敛到严格鞍点的概率为零[1]。证明需要把迭代写成微分同胚，再用中心稳定流形定理，篇幅较长，读者可查阅原文。

这个结论有三个限度。第一，它的随机性只来自初值，之后的迭代完全确定。第二，它只排除收敛到严格鞍点，不说明会收敛到局部极小点，迭代也可能根本不收敛。第三，它是渐近的，没有说需要多少步。第三点不能靠更细的分析补上：要让 $|x_1|$ 增长到 0.5，例中的轮数如下。

[1] J. D. Lee, M. Simchowitz, M. I. Jordan, B. Recht, *Gradient Descent Only Converges to Minimizers* In Proceedings of the 29th Conference on Learning Theory, 2016, pp. 1246–1257

$x_1^{(0)}$	10^{-3}	10^{-6}	10^{-9}	10^{-12}
轮数	16	33	50	67

表 10.4 目标 (10.1)上 $|x_1^{(t)}|$ 首次达到 0.5 所需的轮数。

初值的 x_1 可以任意接近零，轮数就可以任意大。所以普通梯度下降没有一个对所有初值都成立的有限步上界。要得到有限步的保证，必须让算法自己把迭代点推离稳定流形。

主要思想：只需要一点扰动 图 10.14用数值实验看这件事。以原点为中心取半径 0.25 的圆盘，把每个点作为初值运行若干步梯度下降，再标出目标没有下降足够多的初值。这些“卡住”的初值组成一条沿 x_2 方向的窄带，步数越多，窄带越窄。

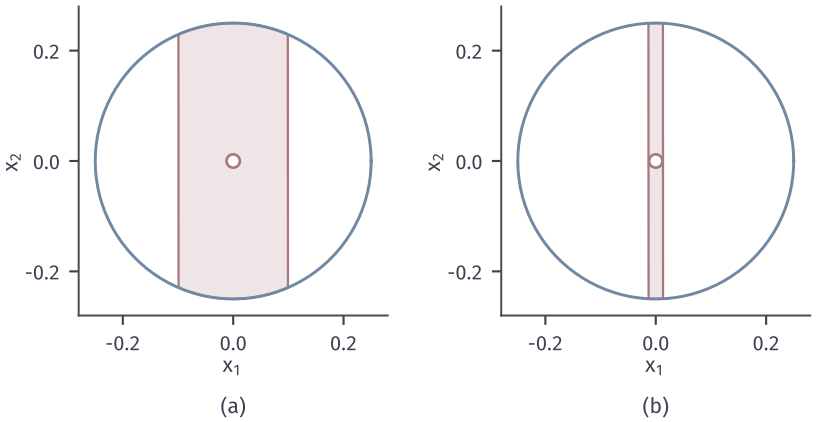


图 10.14 从半径 0.25 的圆盘（蓝线）内出发的梯度下降，步长 1/2。红色窄带内的初值在 T 步后仍有 $f > 1/4 - 0.05$。(a)$T = 3$，带的半宽约 0.099。(b)$T = 8$，带的半宽约 0.013。窄带以外的点都已离开鞍点。

因此，在鞍点附近的小球内随机选一个点，落在窄带里的概率很小。图 10.15是概率的几何含义：窄带的体积与整个球的体积之比。只要球内的点几乎都能离开，加一点随机扰动就够了，扰动不需要很大。

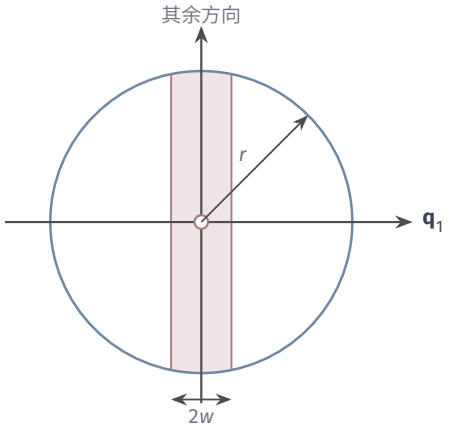


图 10.15　半径 r 的球内，沿 $\boldsymbol{q}_1$ 方向半宽 w 的窄带。均匀随机的扰动落入窄带的概率就是两者的体积比。窄带外的点在 $\boldsymbol{q}_1$ 上的分量至少是 w。

先在二次目标上把这件事算清楚，此时 $\boldsymbol{x}^\star$ 处的线性近似 (10.21)是精确的，全部论证都能写出来。

定理 10.6　二次目标上的逃离　设 $f(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{H}\boldsymbol{x}$，$\boldsymbol{H} \in \mathbb{R}^{n\times n}$ 对称，$\|\boldsymbol{H}\|_2 \le L$，$\lambda_{\min}(\boldsymbol{H}) = -\gamma < 0$。$\boldsymbol{x}^{(0)}$ 在半径 r 的球内均匀分布，按步长 $1/L$ 作梯度下降，迭代矩阵是 $\boldsymbol{I} - \boldsymbol{H}/L$。给定 $F > 0$，$\delta \in (0,1)$，若

$$T \ge \frac{L}{\gamma}\ln\frac{4n\,(Lr^2 + 2F)}{\pi\gamma\,\delta^2 r^2}, \tag{10.22}$$

则至少以 $1-\delta$ 的概率，

$$f(\boldsymbol{x}^{(T)}) \le -F. \tag{10.23}$$

证明　设 $c_i = \langle \boldsymbol{x}^{(0)}, \boldsymbol{q}_i\rangle$，$\boldsymbol{q}_1$ 对应 $-\gamma$。证明分三步。

第一步估计 c_1 不太小的概率。令 $w > 0$，事件 $|c_1| \le w$ 是球内半宽 w 的窄带，它的体积不超过宽度 $2w$ 乘以 $(n-1)$ 维截面的最大体积。记 V_m 为 m 维单位球的体积，于是

$$\mathbb{P}\big(|c_1| \le w\big) \le \frac{2w\,r^{n-1}V_{n-1}}{r^n V_n} = \frac{2w}{r}\cdot\frac{V_{n-1}}{V_n}.$$

单位球体积比由 Gamma 函数给出，再用 Wendel 不等式 $\Gamma(x+\tfrac12)/\Gamma(x)\le\sqrt{x}$，取 $x=\frac{n+1}{2}$，得到

$$\frac{V_{n-1}}{V_n}=\frac{\Gamma(\frac{n}{2}+1)}{\sqrt{\pi}\,\Gamma(\frac{n+1}{2})}\le\sqrt{\frac{n+1}{2\pi}}\le\sqrt{\frac{n}{\pi}}.$$

取 $w=\frac{r\delta}{2}\sqrt{\pi/n}$，窄带的概率不超过 δ。所以至少以 $1-\delta$ 的概率，

$$c_1^2\ge w^2=\frac{\pi\delta^2 r^2}{4n}.$$

第二步写出迭代的目标值。$\boldsymbol{x}^{(T)}$ 在 $\boldsymbol{q}_i$ 上的分量是 $(1-\lambda_i/L)^T c_i$，所以

$$f(\boldsymbol{x}^{(T)})=\frac12\sum_i\lambda_i\Big(1-\frac{\lambda_i}{L}\Big)^{2T}c_i^2.$$

对 $\lambda_i\ge0$ 的项，$0\le1-\lambda_i/L\le1$，这些项的和不超过 $\frac12 L\sum_i c_i^2\le\frac12 Lr^2$。对 $\lambda_i<0$ 的项，它们都不大于零，只保留 $\boldsymbol{q}_1$ 这一项，得到

$$f(\boldsymbol{x}^{(T)})\le\frac12 Lr^2-\frac12\gamma\Big(1+\frac{\gamma}{L}\Big)^{2T}c_1^2.$$

第三步确定步数。要使右端不超过 $-F$，只需

$$\Big(1+\frac{\gamma}{L}\Big)^{2T}\ge\frac{Lr^2+2F}{\gamma c_1^2}.$$

由 $\gamma\le L$ 和不等式 $\ln(1+y)\ge y/2$（$0\le y\le1$），左端的对数至少是 $T\gamma/L$。代入 c_1^2 的下界，条件 (10.22)恰好保证上式成立。 ∎

定理把扰动的作用说清楚了。步数的主要部分是 L/γ，即放大一倍需要的步数。维数 n 和失败概率 δ 都在对数里，这是因为分量按指数增长，初值小一个倍数只增加常数步。高维时随机向量在任一方向上的分量约为 $r/\sqrt{n}$，这个 $\sqrt{n}$ 只通过 $\ln n$ 进入步数。

例中在二次近似 $\mathrm{diag}(-1,1)$ 上取 $n=2$，$L=2$，$\gamma=1$，$r=0.05$，$F=0.05$，$\delta=0.1$，式 (10.22)的右端约为 18.6，所以 $T=19$ 就够了。

图 10.16用模拟检验定理。Hessian 取 $\mathrm{diag}(-\gamma,1,\dots,1)$，其余参数同上，统计达到 $f\le-F$ 的步数。(a) 中维数从 2 增加到 10^5，中位数只从 7 增加到 20。(b) 中步数随 γ 减小按 $1/\gamma$ 增长。上界比实际步数略大，但两种依赖关系都吻合。

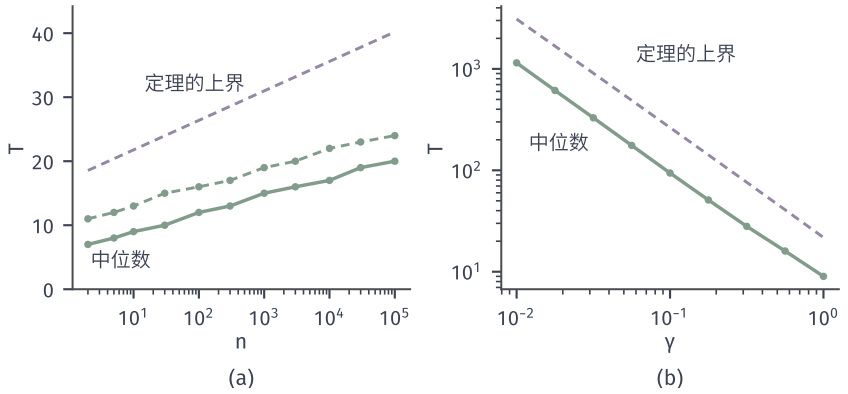


图 10.16　二次目标上达到 $f \le -F$ 所需步数的模拟，每组 3000 次，$L = 2$，$r = 0.05$，$F = 0.05$，Hessian 取 $\mathrm{diag}(-\gamma, 1, \dots, 1)$。绿色实线是中位数，绿色虚线是 90% 分位数，紫色虚线是式 (10.22)在 $\delta = 0.1$ 时的上界。(a)$\gamma = 1$，步数随维数 n 对数增长。(b)$n = 10$，步数约与 $1/\gamma$ 成正比。

把上面的想法组成算法就是**扰动梯度法**（perturbed gradient method）：平时走梯度步；梯度小时加一次随机扰动，再运行一段固定长度的梯度步作为检验。目标下降了足够多，说明确实离开了鞍点，继续；否则就认为这里没有明显的负曲率，返回扰动之前的点。

变量　算法要维护的量是：

- $\boldsymbol{x}^{(t)} \in \mathbb{R}^n$，$\boldsymbol{g}^{(t)} \in \mathbb{R}^n$：当前点和梯度；
- $\tilde{\boldsymbol{x}} \in \mathbb{R}^n$，$\tilde{f}$：保存的基点及其目标值，这是可能返回的点；
- $\boldsymbol{\xi} \in \mathbb{R}^n$：扰动，在半径 r 的球内均匀抽取。

初始化　选定起点、步长 $\alpha = 1/L$、梯度容差 ε_g、扰动半径 r、窗口长度 T_{w} 和下降门槛 F。例中沿用上面算出的 $T_{\mathrm{w}} = 19$，

$$\boldsymbol{x}^{(0)} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad \varepsilon_g = 0.1, \quad r = 0.05, \quad F = 0.05.$$

每轮更新　算法反复执行以下步骤，直到第 4 步返回。

1. 计算 $\boldsymbol{g}^{(t)}$。若 $\|\boldsymbol{g}^{(t)}\|_2 > \varepsilon_g$，走一步梯度步并回到第 1 步。例中与上一小节的前四轮相同，得到下面的点，它的梯度范数 0.0625 低于容差：

$$\boldsymbol{x}^{(4)} = \begin{bmatrix} 0 \\ 0.0625 \end{bmatrix}.$$

2. 保存当前点为基点 $\tilde{\boldsymbol{x}}$，记下它的目标值 $\tilde{f}$，抽取 $\boldsymbol{\xi}$，令当前点为 $\tilde{\boldsymbol{x}}+\boldsymbol{\xi}$。例中设抽到 $\boldsymbol{\xi}=(0.03,-0.02)$，于是

$$\tilde{f}\approx 0.2520, \qquad \tilde{\boldsymbol{x}}+\boldsymbol{\xi}=\begin{bmatrix}0.03\\0.0425\end{bmatrix}.$$

3. 从这里开始连续走 T_{w} 步梯度步。例中 x_1 的前几步是

$$0.03,\ 0.0450,\ 0.0674,\ 0.101,\ 0.151,\ 0.225,\ 0.331,\ 0.479,\ 0.664,$$

x_2 每步减半，第 19 步后到达 $(1.000, 0.000)$，目标约为 10^{-15}。

4. 若窗口结束时目标比 $\tilde{f}$ 下降了至少 F，继续回到第 1 步；否则返回 $\tilde{\boldsymbol{x}}$。例中第一次窗口下降了约 $0.252 \geq 0.05$，继续。

这时梯度范数约为 10^{-7}，再次低于容差，于是在 $(1,0)$ 处第二次扰动。为了便于比较，设仍抽到同一个 $\boldsymbol{\xi}$，窗口结束时目标同样约为零，下降量远小于 F，算法返回基点 $\tilde{\boldsymbol{x}}\approx(1,0)$。整个过程用了 44 次梯度：起始 5 次，两个窗口各 19 次，第一个窗口结束时的判断 1 次。

图 10.17画出了这次运行。第一次窗口把迭代点从鞍点带到谷底，第二次窗口只用来确认谷底附近没有可以利用的负曲率。这也说明了成本的构成：确认“没有”和发现“有”花费相同的 T_{w} 步。

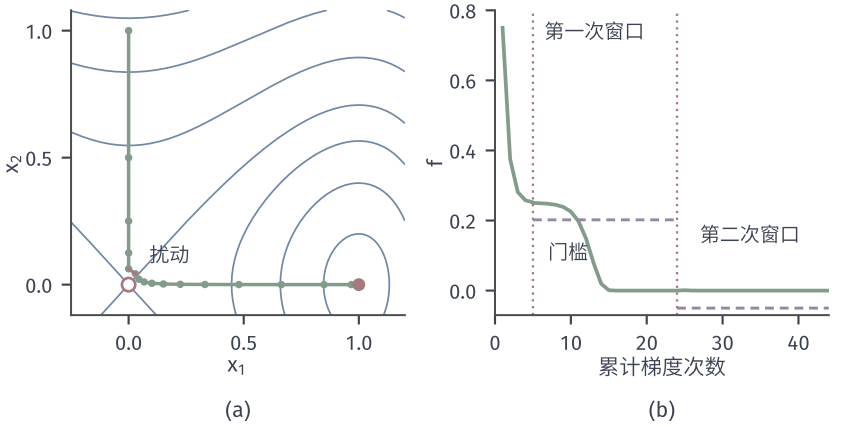


图 10.17 扰动梯度法在目标 (10.1)上的运行，$T_{\mathrm{w}}=19$，$F=0.05$，$\boldsymbol{\xi}=(0.03,-0.02)$。(a) 绿线是路径，红色短线是扰动。(b) 目标值随累计梯度次数的变化，红色点线是触发扰动的时刻，紫色虚线是各窗口要求达到的门槛。第一次窗口越过门槛，第二次窗口没有。

一般目标上的保证 定理 10.6只对二次目标成立。目标不是二次时，Hessian 会随位置变化，放大过程可能被打断，所以需要 Hessian 的 Lipschitz 条件来控制窗口内的偏差。参数按下面的方式联合选取时，有如下保证[2]。

[2] C. Jin, R. Ge, P. Netrapalli, S. M. Kakade, M. I. Jordan, *How to Escape Saddle Points Efficiently* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1724–1732

定理 10.7 扰动梯度法的高概率保证 设 f 下有界，∇f 是 L-Lipschitz 的，$\nabla^2 f$ 是 M-Lipschitz 的，$\Delta_f = f(\boldsymbol{x}^{(0)}) - f_{\inf}$，$\varepsilon \le L^2/M$。取 $\alpha = 1/L$，半径 r、窗口 T_{w} 和门槛 F 按 $L, M, \varepsilon, \delta, n, \Delta_f$ 确定，则至少以 $1-\delta$ 的概率，扰动梯度法返回的点满足

$$\|\nabla f(\tilde{\boldsymbol{x}})\|_2 \le \varepsilon, \qquad \lambda_{\min}\big(\nabla^2 f(\tilde{\boldsymbol{x}})\big) \ge -\sqrt{M\varepsilon}, \tag{10.24}$$

所用梯度次数为 $\tilde{O}\big(L\Delta_f/\varepsilon^2\big)$，$\tilde{O}$ 隐去了 $n, 1/\delta, L, M, \Delta_f, 1/\varepsilon$ 的多项对数因子。

证明的核心比二次情形多了一个技巧。不能再按特征分量独立讨论，于是考虑两条从窄带两侧出发、只在 $\boldsymbol{q}_1$ 方向相差 $2w$ 的迭代序列，用 Hessian 的 Lipschitz 条件证明它们的差在窗口内按指数增长，因此两条序列至少有一条离开基点足够远，目标也因此下降足够多。这说明“卡住”的初值不可能在 $\boldsymbol{q}_1$ 方向上有大于 $2w$ 的宽度，窄带的宽度得到了控制。完整论证篇幅较长，读者可查阅[3]。

定理对参数的要求是实质性的。扰动半径、窗口长度和门槛必须与 L、M、ε 和目标下降总量匹配。这里要区分两件事：结论说的是以高概率到达式 (10.24)定义的点，而不是找到局部极小点，更不是全局最优解。

[3] C. Jin, R. Ge, P. Netrapalli, S. M. Kakade, M. I. Jordan, *How to Escape Saddle Points Efficiently* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1724–1732

严格鞍点的结论不能搬到退化驻点 上面的论证依赖指数放大。退化驻点上没有负特征值，放大是多项式的。比较两个一元函数，步长取 $\alpha = \frac{1}{2}$：

$$-\frac{1}{2}y^2: \quad y^{(t+1)} = \frac{3}{2}y^{(t)}; \qquad -\frac{1}{4}y^4: \quad y^{(t+1)} = y^{(t)} + \frac{1}{2}\big(y^{(t)}\big)^3.$$

前者每步放大常数倍，从 $y^{(0)}$ 到 0.5 只要 $\log_{1.5}(0.5/y^{(0)})$ 步。后者可以用微分方程估计：$\mathrm{d}y/\mathrm{d}t \approx \frac{1}{2}y^3$ 给出 $1/y^2$ 随 t 线性减小，所需步数约为 $1/(y^{(0)})^2$。从 $y^{(0)} = 0.01$ 出发，两者的实际步数分别是 10 和 10002。图 10.18比较了这两种依赖。

10.1 驻点的类型
10.2 负曲率的检测
10.3 离开鞍点
10.3.1 负曲率步
10.3.2 扰动梯度法
10.3.3 利用非正定模型
10.4 停止条件与计算成本
10.5 本章小结

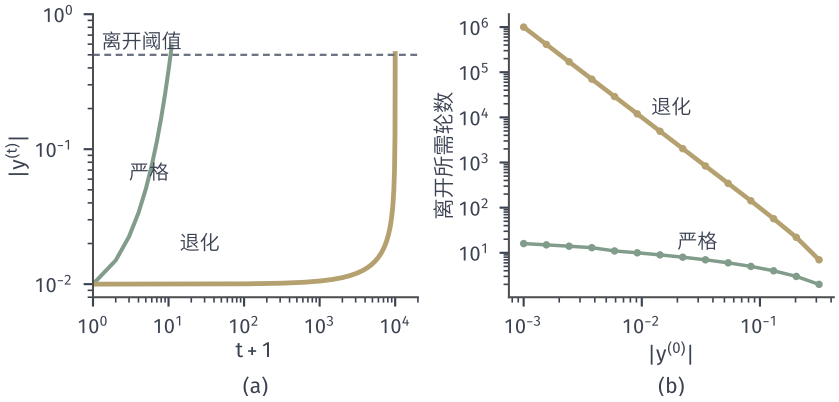


图 10.18 严格鞍点（绿，$-y^2/2$）与退化驻点（黄，$-y^4/4$）上步长 1/2 的梯度下降。(a) 从 $y^{(0)} = 0.01$ 出发的 $|y^{(t)}|$，虚线是离开阈值 0.5。(b) 离开所需轮数随初值大小的变化，严格鞍点按对数增长，退化驻点按 $1/(y^{(0)})^2$ 增长。

在一个由 $x_1^2 - x_2^4$ 描述的退化鞍点上，扰动梯度法的窗口 T_{w} 按严格鞍点设计，时间内分量几乎不长，窗口结束时目标没有明显下降，算法就返回基点。这并不违反定理 10.7：基点的 $\lambda_{\min} = 0 \geq -\sqrt{M\varepsilon}$，它满足定理宣称的条件，只是这个条件本来就不排除退化鞍点。

10.3.3 利用非正定模型

二阶方法手里本来就有曲率矩阵。第 7章和第 9章对不定矩阵采取了两种态度：前者把矩阵修正成正定的，后者保留矩阵原样，用半径把模型关起来。这里比较两种态度在鞍点附近的差别，特别是哪种能利用负曲率。

信赖域模型怎样使用负曲率 回顾第 9章的子问题：

$$\min_{\|\boldsymbol{p}\|_2 \leq \Delta} m(\boldsymbol{p}) = f(\boldsymbol{x}) + \langle \boldsymbol{g}, \boldsymbol{p} \rangle + \frac{1}{2}\boldsymbol{p}^{\top}\boldsymbol{B}\boldsymbol{p}. \tag{10.25}$$

$\boldsymbol{p}$ 是全局解的充要条件是存在 $\lambda \geq 0$，使

$$(\boldsymbol{B} + \lambda \boldsymbol{I})\boldsymbol{p} = -\boldsymbol{g}, \qquad \boldsymbol{B} + \lambda \boldsymbol{I} \succeq \boldsymbol{0}, \qquad \lambda\big(\Delta - \|\boldsymbol{p}\|_2\big) = 0. \tag{10.26}$$

第二个条件说明 $\lambda \geq -\lambda_{\min}(\boldsymbol{B})$。所以 $\boldsymbol{B}$ 不定时 $\lambda > 0$，解一定在边界上：模型沿负曲率方向一直下降，直到碰上半径。这里没有把任何曲率改成正值，负曲率被直接转化成一个长度为 Δ 的步。

在原点取 $\boldsymbol{B} = \mathrm{diag}(-1, 1)$，$\Delta = \frac{1}{2}$，$\boldsymbol{g} = \boldsymbol{0}$。条件 (10.26)给出 $\lambda = 1$，第一个方程 $(\boldsymbol{B} + \boldsymbol{I})\boldsymbol{p} = \boldsymbol{0}$ 只约束 $p_2 = 0$，于是

$$\boldsymbol{p} = \begin{bmatrix} \pm\frac{1}{2} \\ 0 \end{bmatrix}, \qquad m(\boldsymbol{0}) - m(\boldsymbol{p}) = \frac{1}{8}.$$

代回目标，实际下降和两者之比分别是

$$f(\mathbf{0}) - f\big(\tfrac{1}{2}, 0\big) = \frac{1}{4} - \frac{9}{64} = 0.1094, \qquad \rho = \frac{0.1094}{0.125} \approx 0.875.$$

这一步可以接受。梯度精确为零，信赖域仍然走出了一大步，这是只靠梯度的方法做不到的。

修正 Hessian 的用途不同 第 7章的修正让矩阵变成 $\boldsymbol{B} = \boldsymbol{H} + \boldsymbol{E} \succ \mathbf{0}$，解 $\boldsymbol{B}\boldsymbol{d} = -\boldsymbol{g}$，目的是得到下降方向，让线搜索有效。这时 $\boldsymbol{g} = \mathbf{0}$ 意味着 $\boldsymbol{d} = \mathbf{0}$，算法原地不动。

$\boldsymbol{g}$ 很小但不为零时，以谱修正为例，方向沿 $\boldsymbol{q}_i$ 的分量是 $-\langle \boldsymbol{g}, \boldsymbol{q}_i \rangle / |\lambda_i|$，长度正比于梯度，鞍点附近很短。下面在点 $(0.01, 0.0625)$ 上比较两者。由式 (10.2)，该点的数据是

$$\boldsymbol{g} \approx \begin{bmatrix} -0.0100 \\ 0.0625 \end{bmatrix}, \qquad \boldsymbol{H} \approx \operatorname{diag}(-0.9997, 1).$$

谱修正取绝对值，得到的方向和 $\Delta = \frac{1}{2}$ 时子问题的解分别是

$$\boldsymbol{d} \approx \begin{bmatrix} 0.0100 \\ -0.0625 \end{bmatrix}, \qquad \boldsymbol{p} \approx \begin{bmatrix} 0.4990 \\ -0.0309 \end{bmatrix}.$$

子问题的 $\lambda \approx 1.020$，预测下降 0.1309，实际下降 0.1142，$\rho \approx 0.872$，接受。修正方向沿 x_1 的分量只有子问题解的约 2%。图 10.19(a) 画出了这两个方向，(b) 比较后续运行：修正方法配回溯时，x_1 大约每轮翻一倍，要 6 轮才接近 0.77；信赖域 3 轮之内就到了谷底附近，其间有一次拒绝。

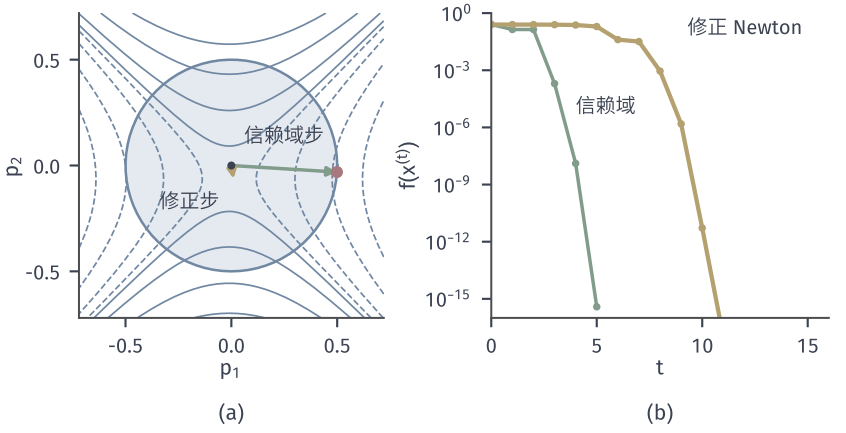


图 10.19 点 $(0.01, 0.0625)$ 处的比较。(a) 蓝线是二次模型的等高线（虚线为负值），浅蓝圆盘半径 $\Delta = 1/2$，绿色箭头指向子问题的解（红点），黄色短箭头是谱修正方向。(b) 从该点出发目标值随轮数的变化，绿线是精确求解子问题的信赖域，黄线是谱修正加 Armijo 回溯。

梯度与负曲率方向正交时　最能说明两种方法差别的是 $\langle \boldsymbol{g}, \boldsymbol{q}_1 \rangle = 0$ 的情形。在点 $(0, 0.0625)$，梯度是 $(0, 0.0625)$，与 $\boldsymbol{e}_1$ 正交。此时条件 (10.26)的第一行变成 $(\lambda - 1)p_1 = 0$，半正定条件要求 $\lambda \geq 1$。取 $\lambda = 1$，第二行和球面条件给出

$$p_2 = -\frac{0.0625}{1+1} = -0.03125, \qquad p_1 = \pm\sqrt{\Delta^2 - p_2^2} \approx \pm 0.4990.$$

这是第 9章所说的困难情形：$\boldsymbol{B} + \lambda \boldsymbol{I}$ 奇异，方程本身不能确定 p_1，要沿 $\boldsymbol{q}_1$ 方向补一个分量才到达边界。这一步的预测下降是 0.1260，$\rho \approx 0.877$。

截断共轭梯度却看不到 $\boldsymbol{e}_1$。它的迭代只在由 $\boldsymbol{g}$ 生成的 Krylov 子空间中进行，这里就是 x_2 轴，第一步就到达 $(0, -0.0625)$，残差为零而停止，预测下降只有约 0.002。图 10.20(a) 是这个点上的模型，(b) 是从 $(0, 1)$ 出发的运行。截断共轭梯度第一步到达原点，$\boldsymbol{g} = \boldsymbol{0}$，算法宣布完成。精确子问题第一步是 $(0.866, -0.5)$，比值 $\rho = 0.8125$，第二步到达 $(1.039, 0)$。

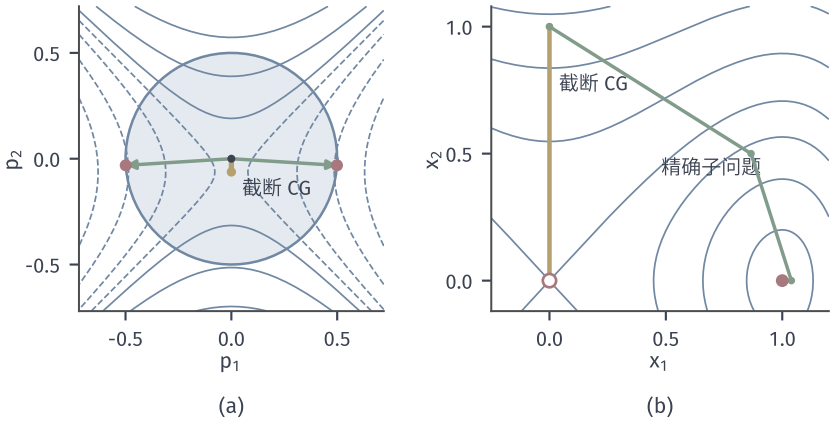


图 10.20　困难情形。(a) 点 $(0, 0.0625)$ 处的模型（蓝线）与半径 $1/2$ 的圆盘，两个红点是子问题的全局解，黄线是截断共轭梯度的结果，它留在 p_2 轴上。(b) 从 $(0, 1)$ 出发、$\Delta^{(0)} = 1$ 的运行：绿线精确求解子问题，黄线用截断共轭梯度，一步到达鞍点后停止。

这里要记住：算出的步是否利用负曲率，由子问题的求解方式决定。使用截断共轭梯度的信赖域，在 $\boldsymbol{g}$ 恰好避开 $\boldsymbol{q}_1$ 时和修正方法一样看不见负曲率。

后续保证的差别　第 9章的二阶保证要求候选步的模型下降满足下面的条件，其中 $\lambda_- = \max\{0, -\lambda_{\min}\}$，$c_2 > 0$ 是常数：

$$\mathrm{pred}(\boldsymbol{p}) \geq c_2 \lambda_- \Delta^2.$$

10.1 驻点的类型
10.2 负曲率的检测
10.3 离开鞍点
10.4 停止条件与计算成本
10.5 本章小结

由此得到

$$\liminf_{t\to\infty} \max\{\|\boldsymbol{g}^{(t)}\|_2,\ \lambda_-^{(t)}\} = 0. \tag{10.27}$$

精确解 $c_2 = \frac{1}{2}$，满足这一条；只有一阶信息的步不满足，保证也就退回到 $\boldsymbol{g}^{(t)} \to \boldsymbol{0}$。

不想精确求解时，可以把第 10.2节的检测嫁接进来。设检测给出 $\boldsymbol{v}$，$\boldsymbol{v}^{\top}\boldsymbol{B}\boldsymbol{v} \le -\gamma$，选符号使 $\langle \boldsymbol{g}, \boldsymbol{v}\rangle \le 0$，把 $\Delta\boldsymbol{v}$ 作为候选步，它的预测下降是

$$m(\boldsymbol{0}) - m(\Delta\boldsymbol{v}) = -\Delta\langle \boldsymbol{g}, \boldsymbol{v}\rangle - \frac{\Delta^2}{2}\boldsymbol{v}^{\top}\boldsymbol{B}\boldsymbol{v} \ge \frac{1}{2}\gamma\Delta^2.$$

只要 γ 不小于 λ_- 的一个固定倍数，例如 $\gamma \ge \frac{1}{2}\lambda_-$，就得到 $c_2 = \frac{1}{4}$，第 9章的论证可以照搬。当然这样一来保证就带上了检测的失败概率。表 10.5总结了各种做法的区别。

做法	在 $\boldsymbol{g}=\boldsymbol{0}$ 的鞍点	结论
修正 Hessian 加线搜索	不动	$\boldsymbol{g}^{(t)} \to \boldsymbol{0}$
信赖域，Cauchy 步或截断 CG	不动	$\boldsymbol{g}^{(t)} \to \boldsymbol{0}$
信赖域，精确子问题	走到边界	式 (10.27)
信赖域，加入负曲率检测	走到边界	同上，带失败概率

表 10.5　几种处理不定矩阵的做法。式 (10.27)的二阶结论只说明子列满足二阶必要条件，不说明极限点是局部极小点。

总之，修正 Hessian 解决的是“方向要下降”，保留不定模型解决的是“负曲率要被利用”。两者的出发点不同，后续能给出的保证也不同，不应混为一谈。

10.4 停止条件与计算成本

算法什么时候可以停，一次运行究竟可以报告什么？第 5章要求比较算法之前固定三件事：误差标准、返回哪个点、计算量怎样累计。这里把这三件事放到二阶情形下落实。

两个容差　只有一个梯度容差无法排除鞍点，所以要同时控制梯度大小和 Hessian 最小特征值的负部。

定义 10.8　近似二阶驻点　给定 $\varepsilon_g > 0$，$\varepsilon_H > 0$，若点 $\boldsymbol{x}$ 满足

$$\|\nabla f(\boldsymbol{x})\|_2 \le \varepsilon_g, \qquad \lambda_{\min}\big(\nabla^2 f(\boldsymbol{x})\big) \ge -\varepsilon_H, \tag{10.28}$$

> 就称它为 $(\varepsilon_g, \varepsilon_H)$近似二阶驻点（approximate second-order stationary point）。

例中 $\varepsilon_g = 0.1$，$\varepsilon_H \approx 0.775$。点 $(0, 0.0625)$ 的梯度范数 0.0625 通过了第一个条件，$\lambda_{\min} = -1$ 没有通过第二个。点 $(0.9686, 0.0039)$ 的梯度范数 0.060，$\lambda_{\min} = 1$，两个都通过。图 10.21(a) 把表 10.3的运行画在这两个量组成的平面上，(b) 在变量空间中画出了两种验收区的差别。

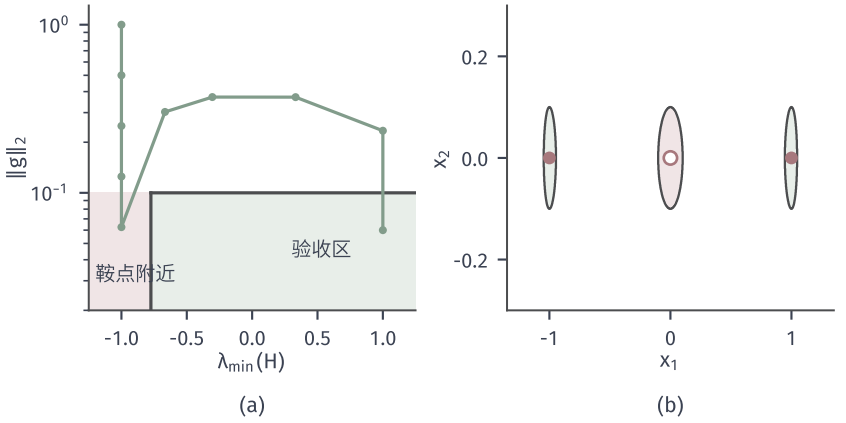


图 10.21　两个容差的验收区，$\varepsilon_g = 0.1$，$\varepsilon_H \approx 0.775$。(a) 横轴是 $\lambda_{\min}(\boldsymbol{H})$，纵轴是 $\|\boldsymbol{g}\|_2$（对数坐标），绿色矩形是验收区，粗线是边界，浅红区梯度合格而曲率不合格，折线是表 10.3的运行。(b) 目标 (10.1)上 $\|\nabla f\|_2 \le \varepsilon_g$ 的三块区域，鞍点周围的一块（浅红）不满足曲率条件，只有两侧（浅绿）满足全部条件。

两个容差怎样搭配　两个容差不是独立的。式 (10.28)对目标下降的限制可以由三次上界直接算出：设半径 r 的球落在引理 10.3的凸集内，对 $\|\boldsymbol{p}\|_2 \le r$，由该引理和式 (10.28)，

$$f(\boldsymbol{x}+\boldsymbol{p}) \ge f(\boldsymbol{x}) - \varepsilon_g r - \frac{1}{2}\varepsilon_H r^2 - \frac{M}{6}r^3. \tag{10.29}$$

三项分别来自梯度、负曲率和 Hessian 的变化。让三项同量级，由后两项得到 $r \sim \varepsilon_H/M$，代入前两项得到 $\varepsilon_g \sim \varepsilon_H^2/M$，于是自然的搭配是

$$\varepsilon_H = \sqrt{M\varepsilon_g}. \tag{10.30}$$

此时取 $r = \sqrt{\varepsilon_g/M}$，式 (10.29)的三项合计给出

$$f(\boldsymbol{x}+\boldsymbol{p}) \ge f(\boldsymbol{x}) - \frac{5}{3}\frac{\varepsilon_g^{3/2}}{\sqrt{M}}.$$

这就是通过验收的点能保证的事：在半径 r 的球内，目标至多还能下降这么多。

通过验收不等于局部极小 式 (10.29)只限制了小球内的下降幅度，并不排除下降。$x_1^2 - x_2^4$ 在原点梯度和 Hessian 的负部都是零，对任意容差都通过验收，而原点不是局部极小点，甚至这个目标没有下界。

容差取得过大也会放过严格鞍点。例中若 $\varepsilon_H = 2$，原点的 $\lambda_{\min} = -1$ 就能通过。

所以报告结果时，应该写“近似二阶驻点，容差为 $(\varepsilon_g, \varepsilon_H)$”，不写“找到了局部极小点”，更不写“找到了最优解”。

返回哪个点 验收条件是针对具体的点的，所以返回的点必须就是验收的那个点。负曲率算法直接返回验收通过的 $\boldsymbol{x}^{(t)}$。扰动梯度法返回窗口开始之前保存的基点 $\tilde{\boldsymbol{x}}$，因为梯度小的判断是在基点上作出的，窗口结束时的点没有经过判断。

要累计哪些计算量 这一节的成本有四类，单位要分开：梯度次数，Hessian 向量积次数，矩阵分解次数，以及扰动窗口的梯度次数。

扰动窗口的次数也有上界。除了最后一次之外，每次窗口都使目标下降至少 F，所以窗口总数不超过 $\Delta_f / F + 1$。例中上界是 16 次窗口，共 304 次梯度，实际只用了 2 次窗口。每次窗口都有失败的可能，失败概率要像下面的检测一样累计。

检测的失败概率也要累计。负曲率算法可能进行多次检测，任何一次“未找到”判断错误都会使算法提前停止。若检测次数不超过 K，每次失败概率取 δ/K，由并的概率不等式，总失败概率不超过 δ，代价只是对数因子 $\ln(K/\delta)$。

检测有两个方向，失败只发生在“未找到”的方向上。每次发现负曲率都是确定的，所以不需要担心算法走错一步。真正的风险是错误地宣布停止。下面把这些成本组合起来。

取 $\gamma_0 = \varepsilon_H/2$，检测精度 $\varepsilon_H/2$，由式 (10.14)，未找到时 $\lambda_{\min} \geq -\varepsilon_H$。把 $\varepsilon_H = \sqrt{M\varepsilon}$ 代入定理 10.5，负曲率步的次数不超过

$$K = \frac{12\sqrt{M}\,\Delta_f}{\varepsilon^{3/2}}. \tag{10.31}$$

用 Lanczos 方法时每次检测 $O(\sqrt{L/\varepsilon_H}\,\ln(nK/\delta))$ 次乘积，总数是

$$O\Big(\frac{\sqrt{L}\,M^{1/4}\Delta_f}{\varepsilon^{7/4}}\ln\frac{nK}{\delta}\Big). \tag{10.32}$$

这个量对 $1/\varepsilon$ 的幂次比梯度步的 $O(L\Delta_f/\varepsilon^2)$ 低 $1/4$，所以在小容差下乘积的总量不会超过梯度的总量。换成幂迭代时，每次检测 $O((L/\varepsilon_H)\ln(nK/\delta))$ 次乘积，总数变成 $O((L\Delta_f/\varepsilon^2)\ln(nK/\delta))$，与梯度步同阶。

表 10.6汇总了各种做法在最坏情形下的曲率成本，表中 $\varepsilon_g=\varepsilon$，$\varepsilon_H=\sqrt{M\varepsilon}$。前三行的梯度次数都不超过 $2L\Delta_f/\varepsilon^2$ 加检测带来的少量读取，扰动梯度法的梯度次数是 $\tilde{O}(L\Delta_f/\varepsilon^2)$，这里的 $\tilde{O}$ 隐去了对数因子。

方法	曲率读取（梯度次数见正文）	保证
梯度下降	无	一阶，确定
负曲率步，特征分解	$O(\sqrt{M}\Delta_f/\varepsilon^{3/2})$ 次分解	二阶，确定
负曲率步，Lanczos	式 (10.32)的次数	二阶，$\geq 1-\delta$
扰动梯度法	无	二阶，$\geq 1-\delta$
信赖域，精确子问题	$O(\varepsilon^{-2})$ 轮，每轮一次分解	二阶，确定

表 10.6　达到式 (10.28)的最坏情形成本，“二阶”指近似二阶驻点，“$\geq 1-\delta$”指成立的概率。信赖域一行由第 9章的轮数估计得到，并依赖半径下界中的常数。

一次实际运行的账　上界比较的是最坏情形，单次运行要按实际次数报告。表 10.7是从 $(0,1)$ 出发、$\varepsilon_g=0.1$、$\varepsilon_H\approx 0.775$ 时各方法的实际计数。

方法	梯度	曲率读取	返回点	通过
梯度下降	5	无	$(0,\ 0.0625)$	否
谱修正 Newton	2	1 次分解	$(0,\ 0)$	否
信赖域，截断 CG	2	1 次乘积	$(0,\ 0)$	否
负曲率步，特征分解	10	2 次分解	$(0.969,\ 0.004)$	是
负曲率步，幂迭代	11	151 次乘积	$(0.981,\ -0.001)$	是
扰动梯度法	44	无	$(1.000,\ 0.000)$	是
信赖域，精确子问题	3	3 次分解	$(1.039,\ 0)$	是

表 10.7　从 $(0,1)$ 出发的实际计数，“通过”指是否满足式 (10.28)。幂迭代用 $L=2$，随机起点的种子固定为 0，检测精度 $\varepsilon_H/2$，失败概率 $\delta=0.05$（两次检测的总失败概率约 0.1），上限由式 (10.12)算得 149 次。

表中前三行的算法都很便宜，但报告的点是鞍点。它们的共同问题是起点在 x_2 轴上，梯度始终看不到 x_1 方向。负曲率步用幂迭代时，第一次检测只用 2 次乘积就找到了方向，其余 149 次全部花在最后一次“未找到”的确认上。

这说明确认“没有负曲率”才是最贵的一步，手段越便宜，这一步越依赖概率。实际程序常常把上限设得比理论值小，这时要如实报告：这样的结果只是经验判断，不再带有定理 10.2的概率保证。

10.1 驻点的类型
10.2 负曲率的检测
10.3 离开鞍点
10.4 停止条件与计算成本
10.5 本章小结

一次报告应该包含什么 把三件事落实到底，一次运行的结论可以写成这样：对目标 (10.1)，从 $(0,1)$ 出发，用幂迭代检测负曲率的交替算法，返回点满足 $\|\nabla f\|_2 \le 0.1$；未找到负曲率的判断由 149 次乘积支持，至少以 0.9 的概率有 $\lambda_{\min} \ge -0.775$；共用 11 次梯度和 151 次 Hessian 向量积。

这样的报告说清了误差标准（两个容差）、返回的点（验收通过的点）、成本（分类计数）和可信度（失败概率）。它没有声称局部极小，也没有声称全局最优，这两件事本章的方法都保证不了。

10.5 本章小结

本章从一个具体的疑问出发：梯度很小的点算不算找到了解。梯度小只说明一阶变化弱，山口和谷底都满足这一点。

驻点按二阶信息分成严格鞍点和二阶驻点。负曲率是确凿的证据，说明这里还能下降；Hessian 正定也是确凿的证据，说明这里是局部极小点。半正定而奇异的情形，二阶信息无法判断，$x_1^2 + x_2^4$ 与 $x_1^2 - x_2^4$ 就是例子。即使确实是局部极小点，也不说明是全局最优解。

负曲率可以只靠 Hessian 向量积发现。幂迭代和 Lanczos 方法从随机起点出发，找到方向时的结论是确定的，未找到时的结论带有失败概率，检测误差和差分误差都要计入。

离开鞍点有三种机制，它们的条件和结论各不相同。

机制	需要的条件	结论
负曲率步	方向、Hessian Lipschitz	每步确定下降 $\frac{2\gamma^3}{3M^2}$
扰动梯度法	梯度、L、M、随机扰动	高概率到达近似二阶驻点
不定模型	子问题使用负曲率	二阶必要条件的下极限

表 10.8 三种离开鞍点的机制。修正 Hessian 只为得到下降方向，它的保证停留在一阶。

检测精度和离开机制共同决定了能够声称的保证。停止时用两个容差描述近似二阶驻点，$\varepsilon_H = \sqrt{M\varepsilon_g}$ 是自然的搭配，它限制了小球内还能下降多少，但不说明这个点是局部极小点。计算量要把梯度、Hessian 向量积、分解和扰动窗口分开统计，并报告确定性保证或相应的失败概率。

到这里，光滑优化中的方向、步长、曲率和成本的框架已经完整。这些方法都假设梯度存在。下一部分研究目标在某些点没有普通梯度时，怎样改用次微分和邻近结构。

第三部分

非光滑优化

Nonsmooth Optimization

阅读指引

绝对值、最大值和稀疏惩罚在某些点上没有普通梯度，而这些点恰恰常常是最优解所在的位置，所以不能把它们当作可以忽略的例外。本部分回答：梯度不存在时，用什么判别最优，又用什么推动迭代。

第 11章先用次微分推广梯度的角色，建立次梯度方法和最优性条件。若目标分成光滑部分和容易处理的非光滑部分，邻近映射可以把非光滑部分留在子问题里精确处理，由此得到邻近梯度法及其加速版本。另一条路线是改变目标：用光滑函数替代尖点，再调用光滑优化的工具，此时需要同时控制替代误差与求解误差。最后介绍用上界或支撑信息构造代理模型的方法。

第 11 章

非光滑优化

用两个特征拟合三个观测，同时希望用到的特征尽量少。一种常见的写法是在最小二乘后面加上系数绝对值的和：

$$F(\boldsymbol{x}) = \frac{1}{2}\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|_2^2+\lambda\|\boldsymbol{x}\|_1, \qquad \boldsymbol{A} = \begin{pmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad \boldsymbol{b} = \begin{pmatrix} 3 \\ 2 \\ -1 \end{pmatrix}, \quad \lambda = 1. \tag{11.1}$$

后面会算出它的解是 $\boldsymbol{x}^\star = (2,0)$：第二个系数恰好等于零。这个零不是巧合，绝对值项的作用正是把解压到坐标轴上。

麻烦也在这里。第 5章和第 6章的方法都要读梯度，$|x_2|$ 在 $x_2 = 0$ 处却没有导数。在解的附近，目标的等高线带着尖角，“梯度为零”这个判据根本无从写起。不可微的点恰好是解所在的点，这是非光滑优化的特点，不能靠“几乎处处可微”绕过去。

本章先回答怎样判断最优：第 11.1节用支撑直线的斜率代替导数。有了这个工具，最直接的做法是把梯度换成次梯度，第 11.2节会看到这样做每步不一定下降，但有限步后的目标差仍可控制，代价是速度很慢。

慢的根源在于把尖点的结构丢掉了。后面三节用三种不同的办法把结构用回来。第 11.3节和第 11.4节把难求导的部分原样保留在一个带二次距离项的小问题里，当这个小问题有闭式解时，就得到 ISTA 和 FISTA。第 11.5节把尖点磨圆，换成一个光滑的目标，再调用光滑优化的方法，这时要同时算清磨圆带来的偏差和求解的误差。第 11.6节在每一轮构造一个容易求解的模型，模型可以是上界，也可以是由次梯度拼成的下界，两者的用法不同。

全章反复使用三个小例子，除式 (11.1)外，还有一维的三段折线和二维的菱形目标：

$$f(x) = \max\left\{-x,\ \frac{x}{2},\ 2x-3\right\}, \qquad f(\boldsymbol{x}) = |x_1| + 2|x_2|. \tag{11.2}$$

两者的最优解都是原点，最优值都是 0，下文分别称为三段折线和菱形目标。

11.1 次微分

11.1 次微分
11.2 次梯度方法
11.3 邻近方法
11.4 复合优化
11.5 光滑化
11.6 代理模型
11.7 本章小结

函数在尖点没有导数，“导数为零”也就无从谈起。于是要问：在不可微的点，用什么量代替梯度，才能判断这个点是否最优？

尖点上的斜率 先看 $f(x)=|x|$。在 $x\neq 0$ 处，唯一的切线同时也是函数图像下方的一条支撑线。在 $x=0$ 处没有切线，但有许多直线穿过原点且整条都不高于函数图像，也就是斜率 s 满足

$$|y|\geq s\,y \qquad \text{对所有 } y.$$

这个不等式对 $s\in[-1,1]$ 成立，超出这个范围就会在某一侧穿到函数上方。图 11.1(a) 画出了其中五条。

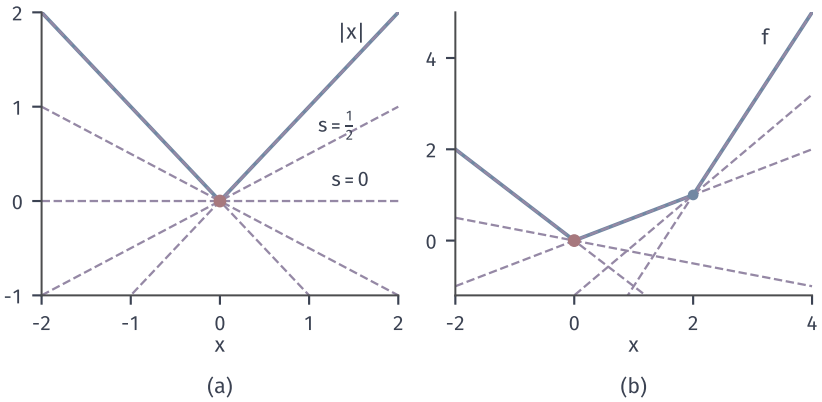


图 11.1 尖点上的支撑直线。蓝线是函数，紫色虚线是不高于函数图像且在该点接触的直线，红点是最优解。(a)$|x|$ 在原点有斜率从 -1 到 1 的一整族支撑线，斜率 $s=0$ 的水平线也在其中。(b) 三段折线在 $x=0$ 处的支撑斜率取遍 $[-1,\frac{1}{2}]$，在 $x=2$ 处取遍 $[\frac{1}{2},2]$，图中各画出几条。

可以把这些直线想成垫在碗底的一块木板。光滑的碗底只有一种放法，木板的倾角就是导数。碗底是尖的，木板可以在一定范围内摇摆，每个摆得开的倾角都是一条合格的支撑线。这个图景有一个边界：木板必须托住整个函数，不只是局部，所以下面的定义只适合凸函数。

定义 11.1 次梯度与次微分 设 $f:\mathbb{R}^n\to\mathbb{R}\cup\{+\infty\}$ 是适当的凸函数，$\boldsymbol{x}\in\operatorname{dom} f$。若向量 $\boldsymbol{g}\in\mathbb{R}^n$ 满足

$$f(\boldsymbol{y})\geq f(\boldsymbol{x})+\langle \boldsymbol{g},\boldsymbol{y}-\boldsymbol{x}\rangle \qquad \text{对所有 } \boldsymbol{y}\in\mathbb{R}^n, \tag{11.3}$$

就称 $\boldsymbol{g}$ 是 f 在 $\boldsymbol{x}$ 处的**次梯度**（subgradient）。全体次梯度组成的集合

$$\partial f(\boldsymbol{x}) = \{\boldsymbol{g} : \ \boldsymbol{g} \text{ 满足式 (11.3)}\} \tag{11.4}$$

称为 f 在 $\boldsymbol{x}$ 处的**次微分**（subdifferential）。对 $\boldsymbol{x} \notin \operatorname{dom} f$，规定 $\partial f(\boldsymbol{x}) = \varnothing$。

式 (11.3)的量词是“对所有 $\boldsymbol{y}$”，这是全局信息。一元时它说的正是支撑线。多元时，右端是一个仿射函数的图像，也就是一张支撑超平面，它把函数的**上图**（epigraph）$\{(\boldsymbol{y}, v) : v \geq f(\boldsymbol{y})\}$ 整个留在上方。

次梯度与第 1章的梯度不是两种东西，可微点上它们重合。下面的定理同时说明，次微分什么时候确实存在。

定理 11.2　次微分的基本性质　设 f 是适当的凸函数。

1. $\partial f(\boldsymbol{x})$ 总是闭凸集（可能为空）。
2. 若 f 在 $\boldsymbol{x} \in \operatorname{int}\operatorname{dom} f$ 处可微，则 $\partial f(\boldsymbol{x}) = \{\nabla f(\boldsymbol{x})\}$。
3. 若 $\boldsymbol{x} \in \operatorname{int}\operatorname{dom} f$，则 $\partial f(\boldsymbol{x})$ 非空且有界。

证明　第一条：每个固定的 $\boldsymbol{y}$，把式 (11.3)看成 $\boldsymbol{g}$ 的条件，都给出一个闭半空间。$\partial f(\boldsymbol{x})$ 是这些闭半空间的交，所以是闭凸集。

第二条：设 $\boldsymbol{g} \in \partial f(\boldsymbol{x})$，$\boldsymbol{d}$ 是任意方向。在式 (11.3)中取 $\boldsymbol{y} = \boldsymbol{x} + s\boldsymbol{d}$，$s > 0$，得到

$$\frac{f(\boldsymbol{x} + s\boldsymbol{d}) - f(\boldsymbol{x})}{s} \geq \langle \boldsymbol{g}, \boldsymbol{d} \rangle.$$

令 $s \to 0^+$，左端趋于 $\langle \nabla f(\boldsymbol{x}), \boldsymbol{d} \rangle$，于是

$$\langle \nabla f(\boldsymbol{x}) - \boldsymbol{g}, \boldsymbol{d} \rangle \geq 0 \qquad \text{对所有 } \boldsymbol{d}.$$

取 $\boldsymbol{d} = \boldsymbol{g} - \nabla f(\boldsymbol{x})$，只能有 $\boldsymbol{g} = \nabla f(\boldsymbol{x})$。反过来，第 1章已经说明，凸函数的切平面是全局下界，所以 $\nabla f(\boldsymbol{x}) \in \partial f(\boldsymbol{x})$。

第三条的有界性：取 $r > 0$ 使闭球 $\{\boldsymbol{y} : \|\boldsymbol{y} - \boldsymbol{x}\|_2 \leq r\}$ 在 $\operatorname{dom} f$ 内，凸函数在这个紧集上有上界 B（把球放进一个小单纯形，函数值不超过顶点值的最大值）。对非零的 $\boldsymbol{g} \in \partial f(\boldsymbol{x})$，取 $\boldsymbol{y} = \boldsymbol{x} + r\boldsymbol{g}/\|\boldsymbol{g}\|_2$，由式 (11.3)，

$$B \geq f(\boldsymbol{y}) \geq f(\boldsymbol{x}) + r\|\boldsymbol{g}\|_2.$$

所以 $\|\boldsymbol{g}\|_2 \leq (B - f(\boldsymbol{x}))/r$。

> 第三条的非空性要用支撑超平面定理：上图是凸集，$(\boldsymbol{x}, f(\boldsymbol{x}))$ 在它的边界上，过这一点存在一张支撑超平面。还需排除竖直的超平面，这一步由 $\boldsymbol{x}$ 是内点保证。 ■

第三条非空性的详细论证可查阅[1]。

边界点上次微分可以是空的。图 11.2(a) 的函数 $f(x) = -\sqrt{x}$（$x \geq 0$，其余为 $+\infty$）是凸的，在 $x = 0$ 处切线竖直。任何有限斜率 s 的直线 sy，在 y 足够小时都高于 $-\sqrt{y}$，因为

$$-\sqrt{y} \geq s\,y \quad \Longleftrightarrow \quad \sqrt{y}\,(1 + s\sqrt{y}) \leq 0,$$

当 $y \to 0^{+}$ 时左端为正。所以 $\partial f(0) = \varnothing$。第三条要求内点，正是为了排除这种情形。

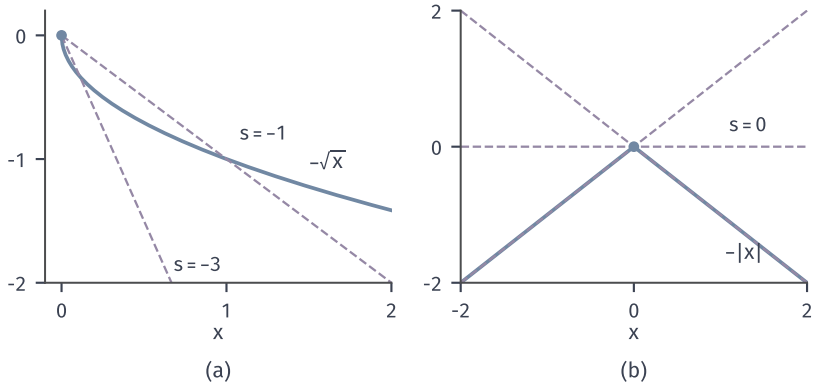


图 11.2　支撑线不存在的两种情形。(a) 凸函数 $-\sqrt{x}$ 在定义域端点切线竖直，紫色虚线（斜率 -1 和 -3）在原点右侧贴近处都高出函数图像，所以次微分为空。(b) 非凸函数 $-|x|$ 的尖点朝上，任何穿过原点的直线都有一部分高于函数，按全局定义没有次梯度。

几个计算　绝对值的次微分由上面的讨论得到：

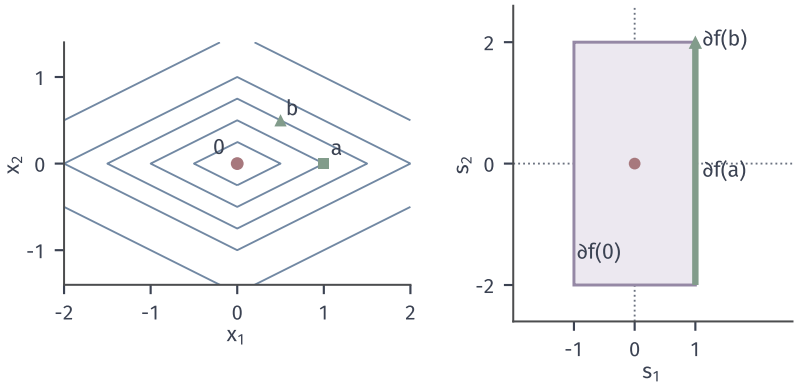
$$\partial |x| = \begin{cases} \{\operatorname{sign}(x)\}, & x \neq 0, \\ [-1, 1], & x = 0. \end{cases} \tag{11.5}$$

坐标可分的函数 $\sum_i c_i |x_i|$（$c_i > 0$）的次微分是各坐标次微分的乘积。这是因为支撑不等式可以逐坐标相加，反过来只让一个坐标变化，就把每个坐标的不等式分离出来。

以菱形目标 $f(\boldsymbol{x}) = |x_1| + 2|x_2|$ 为例，三个代表点的结果是

$$\partial f(0,0) = [-1,1] \times [-2,2], \quad \partial f(1,0) = \{1\} \times [-2,2], \quad \partial f\left(\tfrac{1}{2}, \tfrac{1}{2}\right) = \{(1,2)\}.$$

图 11.3把点放在左边的 $\boldsymbol{x}$ 平面，把次微分放在右边的斜率平面。越是“尖”的点，次微分越大：顶点处是长方形，棱上是线段，光滑的面内缩成一点。



(a) (b)

图 11.3　菱形目标的次微分。(a) 蓝线是 $|x_1| + 2|x_2|$ 的等高线，红点是最优解，$a = (1, 0)$ 在棱上，$b = (\frac{1}{2}, \frac{1}{2})$ 在光滑部分。(b) 斜率平面：紫色长方形是原点的次微分，绿色粗线段是 a 处的次微分，绿色三角是 b 处的梯度。只有长方形包含 $\mathbf{0}$（红点）。

有限个函数取最大值是尖点的另一个来源。最大值的尖点出现在分支交替的地方，这时次微分由活跃分支的梯度张成。把有限个向量的全部凸组合 $\sum_i \theta_i \boldsymbol{g}_i$（$\theta_i \ge 0$，$\sum_i \theta_i = 1$）组成的集合称为它们的**凸包**（convex hull），记作 conv。

定理 11.3　有限最大值的次微分　设 $f_1, \dots, f_m : \mathbb{R}^n \to \mathbb{R}$ 都是可微的凸函数，$f = \max_i f_i$，$I(\boldsymbol{x}) = \{i : f_i(\boldsymbol{x}) = f(\boldsymbol{x})\}$ 是活跃下标集。则

$$\partial f(\boldsymbol{x}) = \operatorname{conv}\{\nabla f_i(\boldsymbol{x}) : \ i \in I(\boldsymbol{x})\}. \tag{11.6}$$

证明　记右端为 $\boldsymbol{K}$。先证 $\boldsymbol{K} \subseteq \partial f(\boldsymbol{x})$。对活跃的 i 和任意 $\boldsymbol{y}$，

$$f(\boldsymbol{y}) \ge f_i(\boldsymbol{y}) \ge f_i(\boldsymbol{x}) + \langle \nabla f_i(\boldsymbol{x}), \boldsymbol{y} - \boldsymbol{x} \rangle = f(\boldsymbol{x}) + \langle \nabla f_i(\boldsymbol{x}), \boldsymbol{y} - \boldsymbol{x} \rangle.$$

把这些不等式按 θ_i 加权相加，就得到凸组合也满足式 (11.3)。

再证反向。假设 $\boldsymbol{g} \in \partial f(\boldsymbol{x})$ 但 $\boldsymbol{g} \notin \boldsymbol{K}$。$\boldsymbol{K}$ 是紧凸集，可以严格分离：存在方向 $\boldsymbol{d}$，使

$$\langle \boldsymbol{g}, \boldsymbol{d} \rangle > \max_{i \in I(\boldsymbol{x})} \langle \nabla f_i(\boldsymbol{x}), \boldsymbol{d} \rangle.$$

当 $s>0$ 足够小时，不活跃的分支仍低于活跃分支，所以

$$f(\boldsymbol{x}+s\boldsymbol{d}) = f(\boldsymbol{x}) + s\max_{i\in I(\boldsymbol{x})}\langle \nabla f_i(\boldsymbol{x}), \boldsymbol{d}\rangle + o(s).$$

另一方面，由式 (11.3)，

$$f(\boldsymbol{x}+s\boldsymbol{d}) \geq f(\boldsymbol{x}) + s\langle \boldsymbol{g}, \boldsymbol{d}\rangle.$$

两式合起来除以 s，令 $s\to 0^+$，与严格不等式矛盾。 ■

用这个定理算三段折线 $f(x)=\max\{-x, x/2, 2x-3\}$。三个分支的斜率是 $-1, \frac{1}{2}, 2$。在 $x=0$ 处前两支活跃，在 $x=2$ 处后两支活跃，所以

$$\partial f(0) = [-1, \tfrac{1}{2}], \qquad \partial f(2) = [\tfrac{1}{2}, 2].$$

其余点只有一支活跃，次微分是单点。图 11.4(b) 把 $\partial f(x)$ 画成 x 的集值图：普通的点对应水平线段上的一个值，尖点对应一条竖直线段，整条曲线是单调上升的台阶。单调上升这件事对应一元凸函数的导数非减。

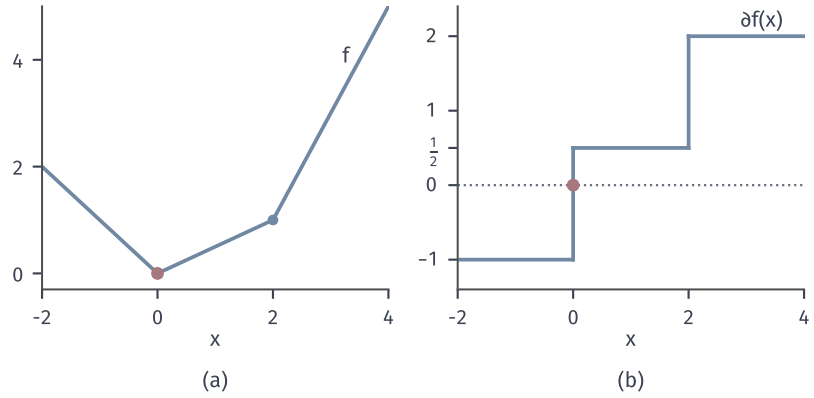


图 11.4 三段折线与它的次微分。(a) 函数图像，红点是最优解。(b) 次微分的集值图像，在两个折点处是竖直线段，点线是斜率为零的水平线。折线在 $x=0$ 处的竖直线段穿过零，这就是最优性条件。

最优性条件 回到本节的问题。式 (11.3)中令 $\boldsymbol{g}=\boldsymbol{0}$，恰好读作“$f(\boldsymbol{y})\geq f(\boldsymbol{x})$ 对所有 $\boldsymbol{y}$ 成立”。判据由此直接得到。

定理 11.4 凸目标的最优性条件 设 f 是适当的凸函数，则

$$\boldsymbol{x}^\star \in \arg\min_{\boldsymbol{x}} f(\boldsymbol{x}) \quad\Longleftrightarrow\quad \boldsymbol{0}\in\partial f(\boldsymbol{x}^\star). \tag{11.7}$$

证明 由次梯度定义 (11.3), $\mathbf{0} \in \partial f(\boldsymbol{x}^\star)$ 与“对所有 $\boldsymbol{y}$, $f(\boldsymbol{y}) \geq f(\boldsymbol{x}^\star)$”是同一句话。 ■

这个判据比第 1章的一阶条件走得更远：它是充要的，而且结论是全局的，因为全局性已经写在定义里了。图 11.4上读这个判据，就是找集值图穿过零线的地方。三段折线在 $x = 0$ 处 $0 \in [-1, \frac{1}{2}]$，是最优解；在 $x = 2$ 处 $0 \notin [\frac{1}{2}, 2]$，不是。图 11.3(b) 中，只有长方形包含原点。

和与复合的规则 复杂的目标由简单的项拼成，希望次微分也能逐项计算。部分结论无条件成立，另一部分需要一个正则条件。下面用 ri 表示**相对内部**（relative interior）：在集合自身张成的仿射子空间内的内点。若 $\operatorname{dom} f$ 有内点，$\operatorname{ri}\operatorname{dom} f$ 就是内部。

定理 11.5 和与仿射复合 设 f_1, f_2, f 是适当的凸函数，$\boldsymbol{A} \in \mathbb{R}^{p\times n}$，$\boldsymbol{c} \in \mathbb{R}^p$。对任意 $\boldsymbol{x}$，

$$\partial f_1(\boldsymbol{x}) + \partial f_2(\boldsymbol{x}) \subseteq \partial (f_1 + f_2)(\boldsymbol{x}), \tag{11.8}$$

$$\boldsymbol{A}^{\top} \partial f(\boldsymbol{A}\boldsymbol{x} + \boldsymbol{c}) \subseteq \partial \big(f(\boldsymbol{A}\,\cdot + \boldsymbol{c})\big)(\boldsymbol{x}). \tag{11.9}$$

若 $\operatorname{ri}\operatorname{dom} f_1 \cap \operatorname{ri}\operatorname{dom} f_2 \neq \varnothing$，式 (11.8)取等号。若 $\boldsymbol{A}$ 的值域经平移后与 $\operatorname{ri}\operatorname{dom} f$ 相交，即存在 $\boldsymbol{x}_0$ 使 $\boldsymbol{A}\boldsymbol{x}_0 + \boldsymbol{c} \in \operatorname{ri}\operatorname{dom} f$，式 (11.9)取等号。

证明 两个包含关系只用定义。若 $\boldsymbol{g}_i \in \partial f_i(\boldsymbol{x})$，把两条支撑不等式相加，就得到 $\boldsymbol{g}_1 + \boldsymbol{g}_2$ 是 $f_1 + f_2$ 的次梯度。若 $\boldsymbol{g} \in \partial f(\boldsymbol{A}\boldsymbol{x} + \boldsymbol{c})$，对任意 $\boldsymbol{y}$，

$$\begin{aligned} f(\boldsymbol{A}\boldsymbol{y} + \boldsymbol{c}) &\geq f(\boldsymbol{A}\boldsymbol{x} + \boldsymbol{c}) + \langle \boldsymbol{g}, \boldsymbol{A}(\boldsymbol{y} - \boldsymbol{x}) \rangle \\ &= f(\boldsymbol{A}\boldsymbol{x} + \boldsymbol{c}) + \langle \boldsymbol{A}^{\top}\boldsymbol{g}, \boldsymbol{y} - \boldsymbol{x} \rangle. \end{aligned}$$

反向的包含要由分离定理构造出分解，正则条件正是分离定理不退化所需要的，篇幅较长，可查阅凸分析的专著。 ■

下面的两个反例说明这些条件不能去掉。

先看和的反例。取 $f_1(x) = -\sqrt{x}$（$x \geq 0$，其余为 $+\infty$），f_2 是 $(-\infty, 0]$ 的约束指标函数。两者的有效定义域只在 0 处相交，相对内部 $(0, \infty)$ 与 $(-\infty, 0)$ 不相交，条件不满足。$f_1 + f_2$ 只在 0 处有限，所以

$$\partial (f_1 + f_2)(0) = \mathbb{R}, \qquad \partial f_1(0) + \partial f_2(0) = \varnothing.$$

左边是整条实线，右边什么都没有，因为前面已经算出 $\partial f_1(0) = \varnothing$。

再看复合的反例。取 $f(u_1,u_2)=-\sqrt{u_2}\,(u_2\ge 0,\text{其余为}+\infty)$，$\boldsymbol{A}x=(x,0)$。值域是直线 $u_2=0$，只碰到 $\operatorname{dom} f$ 的边界。复合函数恒等于 0，次微分是 $\{0\}$，而 $\partial f(x,0)=\varnothing$，等式同样失败。

实际中最常见的情形，至少有一项在全空间有限，比如 $|x|$、$\|\boldsymbol{x}\|_1$ 和光滑项，正则条件自动成立。约束指标函数加有限函数也是如此，只要约束集非空。

外层是一元函数的复合还有一条常用规则：设 $\psi:\mathbb{R}\to\mathbb{R}$ 是非减的凸函数，$c:\mathbb{R}^n\to\mathbb{R}$ 是可微的凸函数，则 $\psi\circ c$ 是凸函数，且

$$\partial(\psi\circ c)(\boldsymbol{x})=\bigl\{s\nabla c(\boldsymbol{x}):\ s\in\partial\psi(c(\boldsymbol{x}))\bigr\}. \tag{11.10}$$

式 (11.10)中“$\supseteq$”的方向可以直接验证。由 ψ 的支撑不等式和 $s\ge 0$（ψ 非减保证了这一点），

$$\psi(c(\boldsymbol{y}))\ge\psi(c(\boldsymbol{x}))+s\bigl(c(\boldsymbol{y})-c(\boldsymbol{x})\bigr)\ge\psi(c(\boldsymbol{x}))+s\langle\nabla c(\boldsymbol{x}),\boldsymbol{y}-\boldsymbol{x}\rangle.$$

第二步用到 $s\ge 0$ 和 c 的凸性。“$\subseteq$”的方向仍需要方向导数的论证。

例如 $f(x)=\max\{0,x^2-1\}$，取 $\psi=\max\{0,\cdot\}$，$c=x^2-1$。在 $x=1$ 处，外层的次微分和内层的导数分别是

$$\partial\psi(0)=[0,1],\qquad c'(1)=2,$$

于是 $\partial f(1)=[0,2]$，这与函数左边斜率 0、右边斜率 2 相符。若外层不单调，凸性本身就可能失败：$|x^2-1|$ 在 $x=0$ 附近向下弯，式 (11.10)不再适用。

贯穿例的最优性　现在可以写出复合目标的最优性条件，并手工核验章首的问题。对

$$F(\boldsymbol{x})=\frac{1}{2}\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|_2^2+\lambda\|\boldsymbol{x}\|_1,\qquad \lambda>0, \tag{11.11}$$

这个问题常称为Lasso（least absolute shrinkage and selection operator）。两项都在全空间有限，和规则取等号。记 $\boldsymbol{w}=\boldsymbol{A}^{\top}(\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b})$，则 $\boldsymbol{x}$ 最优当且仅当对每个坐标

$$w_i=-\lambda\operatorname{sign}(x_i)\quad(x_i\neq 0),\qquad |w_i|\le\lambda\quad(x_i=0). \tag{11.12}$$

非零坐标上光滑项的梯度被绝对值的斜率恰好抵消；零坐标上梯度只要不超过 λ，绝对值在零点的那一段斜率范围足以把它吸收，这个坐标便可以留在零。这就是 Lasso 产生零系数的机制。

验证例 (11.1)的候选解 $\boldsymbol{x}^\star=(2,0)$。先算残差和梯度：

$$\boldsymbol{A}\boldsymbol{x}^\star-\boldsymbol{b}=(-1,0,1),\qquad \boldsymbol{w}=\boldsymbol{A}^{\top}(\boldsymbol{A}\boldsymbol{x}^\star-\boldsymbol{b})=(-1,0).$$

第一坐标 $x_1=2>0$，要求 $w_1=-1$，成立。第二坐标 $x_2=0$，要求 $|w_2|\le 1$，成立。因此 $\boldsymbol{x}^\star=(2,0)$ 是最优解，最优值为

$$F^\star=\frac{1}{2}(1+0+1)+2=3.$$

相对地，原点不是解：此处 $\boldsymbol{w}=-\boldsymbol{A}^{\top}\boldsymbol{b}=(-5,-2)$，两个分量的绝对值都超过 1。

约束问题也可以放进这个框架。设 $\boldsymbol{C}$ 是非空闭凸集，$\iota_{\boldsymbol{C}}$ 是它的约束指标函数。按定义，$\boldsymbol{g}\in\partial\iota_{\boldsymbol{C}}(\boldsymbol{x})$（$\boldsymbol{x}\in\boldsymbol{C}$）当且仅当

$$\langle \boldsymbol{g},\boldsymbol{y}-\boldsymbol{x}\rangle\le 0\qquad \text{对所有 } \boldsymbol{y}\in\boldsymbol{C}. \tag{11.13}$$

满足这个不等式的向量组成 $\boldsymbol{C}$ 在 $\boldsymbol{x}$ 处的**法锥**（normal cone），记作 $\boldsymbol{N}_{\boldsymbol{C}}(\boldsymbol{x})$。若 f 在全空间有限且凸，由定理 11.4和和规则，$\boldsymbol{x}^\star$ 是约束问题的解当且仅当 $\boldsymbol{0}\in\partial f(\boldsymbol{x}^\star)+\boldsymbol{N}_{\boldsymbol{C}}(\boldsymbol{x}^\star)$。例如在 $[0,1]$ 上最小化 $(x-3)^2/2$，解是边界点 $x^\star=1$，此处 $f'(1)=-2$，$\boldsymbol{N}(1)=[0,\infty)$，所以 $0\in -2+[0,\infty)$。这个判据在第 17章会展开成乘子形式。

非凸函数的广义导数　定义 11.1依赖全局不等式，离开凸函数就不再合适。图 11.2(b) 的 $-|x|$ 在原点按全局定义没有次梯度，但它是局部 Lipschitz 函数，尖点处的斜率信息是有意义的。常用的办法是只看局部，把附近可微点的梯度取极限。

对局部 Lipschitz 函数 f，几乎处处可微，令 $\boldsymbol{D}$ 为可微点集合，定义Clarke **次微分**（Clarke subdifferential）

$$\partial_{\mathrm{C}} f(\boldsymbol{x})=\operatorname{conv}\Big\{\lim_{k\to\infty}\nabla f(\boldsymbol{x}^{(k)}):\ \boldsymbol{x}^{(k)}\to\boldsymbol{x},\ \boldsymbol{x}^{(k)}\in\boldsymbol{D}\Big\}. \tag{11.14}$$

这里的 (k) 是取极限用的序列编号。凸函数的 Clarke 次微分与 ∂f 相同；f 连续可微时它就是 $\{\nabla f\}$。对 $-|x|$，$\partial_{\mathrm{C}} f(0)=[-1,1]$，包含 0，但原点却是极大点。

可见 $\boldsymbol{0}\in\partial_{\mathrm{C}} f(\boldsymbol{x})$ 只是局部最优的必要条件，与光滑非凸问题的“驻点”处于同一地位，不能得出全局或局部最优的结论[2]。本章其余部分遇到非凸目标时只用一种形式：f 连续可微但可以非凸，r 是凸函数，把 $\nabla f(\boldsymbol{x})+\partial r(\boldsymbol{x})$ 作为 $f+r$ 的广义次微分，r 局部 Lipschitz 时它正是 Clarke 次微分。

[2] F. H. Clarke, *Optimization and Nonsmooth Analysis*, SIAM, 1990

11.1 次微分
11.2 次梯度方法
11.3 邻近方法
11.4 复合优化
11.5 光滑化
11.6 代理模型
11.7 本章小结

对象	判据	是否充分	结论范围
光滑函数	$\nabla f = \mathbf{0}$	否	局部最优的必要条件
光滑凸函数	$\nabla f = \mathbf{0}$	是	全局最优
非光滑凸函数	$\mathbf{0} \in \partial f$	是	全局最优
局部 Lipschitz 函数	$\mathbf{0} \in \partial_C f$	否	局部最优的必要条件

表 11.1 不同函数类上的一阶判据。是否充分取决于凸性，与是否光滑无关。

表 11.1汇总了这些判据。非光滑不会削弱判据的强度，凸性才决定“驻点”能否等于最优解。

11.2 次梯度方法

有了次梯度，最直接的算法是把梯度下降里的梯度换掉。接下来要弄清：这样换了之后，每一步还是不是在下山？如果不是，靠什么保证有限步之后的目标差可以控制？

主要思想 设 $f : \mathbb{R}^n \to \mathbb{R}$ 是凸函数，每次可以读取一个函数值和一个次梯度。这种只给函数值和次梯度的读取方式常称为黑箱。**次梯度法**（subgradient method）的迭代是

$$\boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} - \alpha^{(t)} \boldsymbol{g}^{(t)}, \qquad \boldsymbol{g}^{(t)} \in \partial f(\boldsymbol{x}^{(t)}). \tag{11.15}$$

这里 $\boldsymbol{g}^{(t)}$ 的记号沿用了梯度的缩写，表示读到的那一个次梯度。

先看第一个差别：$-\boldsymbol{g}^{(t)}$ 不一定是下降方向。取菱形目标 $f(\boldsymbol{x}) = |x_1| + 2|x_2|$，当前点 $\boldsymbol{x} = (1, 0)$，$f(\boldsymbol{x}) = 1$。由上节的计算，$\boldsymbol{g} = (1, 2)$ 是一个次梯度。沿 $-\boldsymbol{g}$ 走 α：

$$\boldsymbol{x}^{+} = (1 - \alpha, -2\alpha), \qquad f(\boldsymbol{x}^{+}) = 1 - \alpha + 4\alpha = 1 + 3\alpha.$$

无论 $\alpha > 0$ 多小，目标都上升。第二分量离开零点付出的代价 4α 超过了第一分量的收益。第 5章的下降引理在这里完全不成立，线搜索也无从进行：沿这个方向根本没有更低的点。

但走这一步并不是白走。到最优解 $\boldsymbol{x}^\star = \mathbf{0}$ 的距离的平方变成

$$(1 - \alpha)^2 + 4\alpha^2 = 1 - 2\alpha + 5\alpha^2,$$

当 $\alpha < \frac{2}{5}$ 时比 1 小。目标上升了，到解的距离却缩短了，图 11.5画出了这个现象。

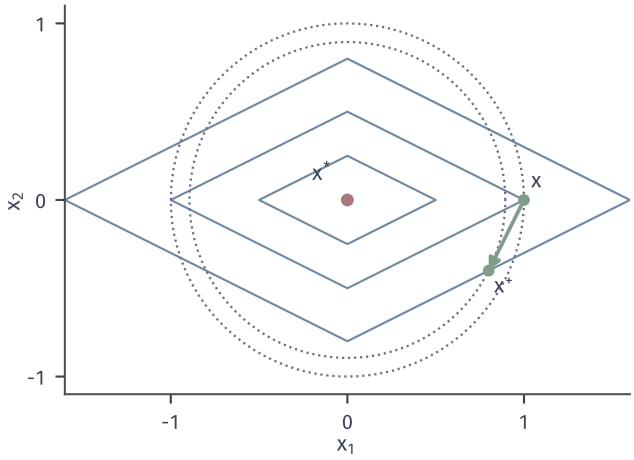


图 11.5 次梯度步不是下降步。蓝线是菱形目标的等高线，由内到外对应 $f = 0.5, 1, 1.6$。从 $\boldsymbol{x} = (1, 0)$ 沿 $-\boldsymbol{g} = -(1, 2)$ 走 $\alpha = 0.2$ 到 $\boldsymbol{x}^+ = (0.8, -0.4)$，点越过了 $f = 1$ 的等高线，目标升到 1.6。两个灰色点线圆以 $\boldsymbol{x}^\star$（红点）为心，新点在内圆上，到解的距离从 1 降到约 0.894。

原因在支撑不等式 (11.3)。取 $\boldsymbol{y} = \boldsymbol{x}^\star$ 并移项，得到

$$\langle \boldsymbol{g}^{(t)}, \boldsymbol{x}^{(t)} - \boldsymbol{x}^\star \rangle \geq f(\boldsymbol{x}^{(t)}) - f^\star \geq 0. \tag{11.16}$$

所以 $-\boldsymbol{g}^{(t)}$ 与“指向解的方向” $\boldsymbol{x}^\star - \boldsymbol{x}^{(t)}$ 夹角不超过直角，目标差越大，这个内积越大。次梯度不保证等高线向内，只保证指向解的那一侧。下面的分析就用距离而不是目标值作为进展的度量。

计算过程 用菱形目标 $f(\boldsymbol{x}) = |x_1| + 2|x_2|$ 作例子。

变量

- $\boldsymbol{x}^{(t)} \in \mathbb{R}^n$：当前点；例中 $n = 2$。
- $\boldsymbol{g}^{(t)}$：读到的一个次梯度；例中约定把 $\operatorname{sign}(0)$ 取成 $+1$，即 $\boldsymbol{g} = (\pm 1, \pm 2)$，这样 $G = \sqrt{5}$。
- $\alpha^{(t)}$：步长；例中先用固定的 $\alpha = 0.3$。
- f_{best} 与 $\boldsymbol{x}_{\text{best}}$：目前最好的值和点。

初始化 选起点 $\boldsymbol{x}^{(0)}$，令 $f_{\text{best}} = f(\boldsymbol{x}^{(0)})$。例中 $\boldsymbol{x}^{(0)} = (1, 1)$，$f_{\text{best}} = 3$，到解的距离 $R = \sqrt{2}$。

每轮更新

1. 读取 $\boldsymbol{g}^{(t)} \in \partial f(\boldsymbol{x}^{(t)})$。例中第一轮 $\boldsymbol{g}^{(0)} = (1, 2)$。
2. 由式 (11.15)计算新点。例中第一轮

$$\boldsymbol{x}^{(1)} = (1, 1) - 0.3\,(1, 2) = (0.7, 0.4).$$

3. 计算 $f(\boldsymbol{x}^{(t+1)})$，若比 f_{best} 小就更新。例中 $f(\boldsymbol{x}^{(1)}) = 1.5$，$f_{\text{best}} = 1.5$。

后续各轮的结果如下，$\boldsymbol{g}^{(t)}$ 按当前点的符号取得：

$$\begin{aligned}
\boldsymbol{x}^{(2)} &= (0.7, 0.4) - 0.3\,(1, 2) = (0.4, -0.2), && f = 0.8,\\
\boldsymbol{x}^{(3)} &= (0.4, -0.2) - 0.3\,(1, -2) = (0.1, 0.4), && f = 0.9,\\
\boldsymbol{x}^{(4)} &= (0.1, 0.4) - 0.3\,(1, 2) = (-0.2, -0.2), && f = 0.6,\\
\boldsymbol{x}^{(5)} &= (-0.2, -0.2) - 0.3\,(-1, -2) = (0.1, 0.4), && f = 0.9.
\end{aligned}$$

第三轮目标从 0.8 升到 0.9，第五轮回到了 $\boldsymbol{x}^{(3)}$，此后在 $(0.1, 0.4)$ 和 $(-0.2, -0.2)$ 之间循环。这里没有收敛，f_{best} 停在 0.6。迭代到预定的步数 T 结束，或在已知下界时目标差足够小时结束。最终得到的不是最后一个点，而是 $\boldsymbol{x}_{\text{best}} = (-0.2, -0.2)$。图 11.6画出了路径与目标值。

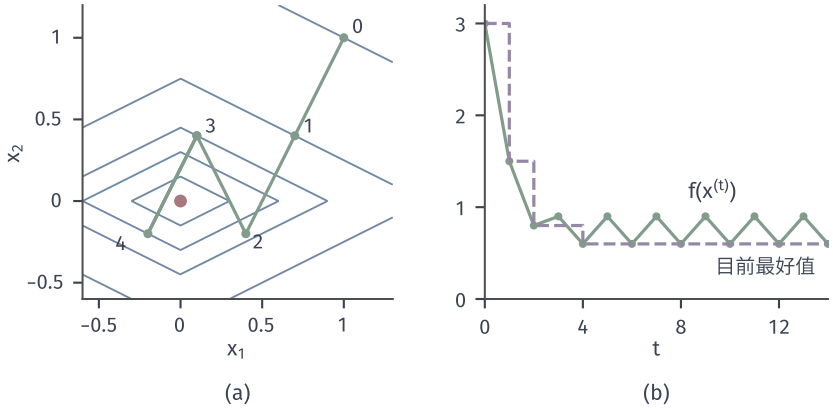


图 11.6 固定步长 $\alpha = 0.3$ 的次梯度法。(a) 菱形目标的等高线上前 5 步的路径（绿色），数字是迭代编号，最后两点形成循环。(b) 绿线是目标值 $f(\boldsymbol{x}^{(t)})$，反复升降；紫色虚线是目前最好值，在 0.6 处不再改善。

距离的递推 把更新代入距离的平方并展开：

$$\|\boldsymbol{x}^{(t+1)} - \boldsymbol{x}^\star\|_2^2 = \|\boldsymbol{x}^{(t)} - \boldsymbol{x}^\star\|_2^2 - 2\alpha^{(t)}\langle \boldsymbol{g}^{(t)}, \boldsymbol{x}^{(t)} - \boldsymbol{x}^\star\rangle + (\alpha^{(t)})^2 \|\boldsymbol{g}^{(t)}\|_2^2.$$

由式 (11.16)替换中间一项，得到

$$\|\boldsymbol{x}^{(t+1)} - \boldsymbol{x}^\star\|_2^2 \le \|\boldsymbol{x}^{(t)} - \boldsymbol{x}^\star\|_2^2 - 2\alpha^{(t)}\big(f(\boldsymbol{x}^{(t)}) - f^\star\big) + (\alpha^{(t)})^2 \|\boldsymbol{g}^{(t)}\|_2^2. \tag{11.17}$$

式 (11.17)中，目标差是“推进”，步长平方乘次梯度范数是“偏离”。步长小的时候偏离是二阶量，推进是一阶量，所以只要目标差还不小，距离就会缩短。目标差趋近于零时偏离占上风，迭代在解附近抖动，这决定了步长必须逐渐减小。

定理 11.6　次梯度法的目标差界　设 $f:\mathbb{R}^n\to\mathbb{R}$ 是凸函数，最优解 $\boldsymbol{x}^\star$ 存在，所有读到的次梯度满足 $\|\boldsymbol{g}^{(t)}\|_2\le G$，$\|\boldsymbol{x}^{(0)}-\boldsymbol{x}^\star\|_2\le R$。按式 (11.15)迭代 T 步，记

$$\bar{\boldsymbol{x}}^{(T)}=\frac{\sum_{t=0}^{T-1}\alpha^{(t)}\boldsymbol{x}^{(t)}}{\sum_{t=0}^{T-1}\alpha^{(t)}},\qquad f_{\text{best}}^{(T)}=\min_{0\le t<T} f(\boldsymbol{x}^{(t)}),\tag{11.18}$$

则两者都满足

$$\max\{f(\bar{\boldsymbol{x}}^{(T)}),\,f_{\text{best}}^{(T)}\}-f^\star\le\frac{R^2+G^2\sum_{t=0}^{T-1}(\alpha^{(t)})^2}{2\sum_{t=0}^{T-1}\alpha^{(t)}}.\tag{11.19}$$

特别地，预先确定 T 并取固定步长 $\alpha^{(t)}=R/(G\sqrt{T})$ 时，上界为

$$\frac{RG}{\sqrt{T}}.\tag{11.20}$$

证明　把式 (11.17)对 $t=0,\dots,T-1$ 相加，左右的距离项错项相消，只剩首尾：

$$\|\boldsymbol{x}^{(T)}-\boldsymbol{x}^\star\|_2^2\le R^2-2\sum_{t=0}^{T-1}\alpha^{(t)}\big(f(\boldsymbol{x}^{(t)})-f^\star\big)+G^2\sum_{t=0}^{T-1}(\alpha^{(t)})^2.$$

左端非负，移项后得到

$$2\sum_{t=0}^{T-1}\alpha^{(t)}\big(f(\boldsymbol{x}^{(t)})-f^\star\big)\le R^2+G^2\sum_{t=0}^{T-1}(\alpha^{(t)})^2.$$

最好值的目标差不超过各项目标差的 $\alpha^{(t)}$ 加权平均。平均点由 Jensen 不等式（凸函数在加权平均点的值不超过函数值的同一加权平均，这由凸函数的定义对权重个数归纳得到）也满足

$$f(\bar{\boldsymbol{x}}^{(T)})-f^\star\le\frac{\sum_t\alpha^{(t)}\big(f(\boldsymbol{x}^{(t)})-f^\star\big)}{\sum_t\alpha^{(t)}}.$$

两者除以 $2\sum_t\alpha^{(t)}$，就是式 (11.19)。

> 取 $\alpha^{(t)}=\alpha$ 时，右端是 $(R^2+TG^2\alpha^2)/(2T\alpha)$，关于 α 在 $\alpha=R/(G\sqrt{T})$ 处最小，代入即得式 (11.20)。 ■

定理的条件都用上了。凸性给出式 (11.16)；次梯度有界使偏离项可控，Lipschitz 连续的函数自动满足这一条，常数 G 就是 Lipschitz 常数；最优解存在，R 才有意义。结论说的是平均点或最好点，最后一点 $\boldsymbol{x}^{(T)}$ 不在其中。

回到上面的小例子，式 (11.19)对 f_{best} 的预言是 $T=5$ 时不超过

$$\frac{2+5\cdot 5\cdot 0.09}{2\cdot 5\cdot 0.3}=\frac{4.25}{3}\approx 1.417,$$

实际的 $f_{\text{best}}=0.6$。当 $T\to\infty$ 时，这个界趋于 $G^2\alpha/2=0.75$，固定步长的上界也只能给到一个邻域。

步长规则　式 (11.19)告诉我们要什么：分子增长比分母慢，这需要 $\sum_t \alpha^{(t)}=\infty$，同时 $\alpha^{(t)}\to 0$ 使平方和相对于和可以忽略。满足这两条的递减步长，如 $\alpha^{(t)}=c/\sqrt{t+1}$，右端趋于 0。它们不需要预先知道 T，代价是界多出一个对数因子。

若最优值 $f^\star$ 已知，可以直接优化式 (11.17)的右端。关于 $\alpha^{(t)}$ 求最小，得到Polyak 步长（Polyak step size）：

$$\alpha^{(t)}=\frac{f(\boldsymbol{x}^{(t)})-f^\star}{\|\boldsymbol{g}^{(t)}\|_2^2}. \tag{11.21}$$

把它代回式 (11.17)，得到每步距离的减少量：

$$\|\boldsymbol{x}^{(t+1)}-\boldsymbol{x}^\star\|_2^2\le\|\boldsymbol{x}^{(t)}-\boldsymbol{x}^\star\|_2^2-\frac{(f(\boldsymbol{x}^{(t)})-f^\star)^2}{\|\boldsymbol{g}^{(t)}\|_2^2}.$$

相加后同样得到 $\min_{t<T} f(\boldsymbol{x}^{(t)})-f^\star\le RG/\sqrt{T}$，不用事先知道 R、G 和 T，但要知道 $f^\star$，这在部分问题上成立，例如已知最优值为零的可行性问题。例中从 $(1,0)$、$\boldsymbol{g}=(1,2)$ 出发，$\alpha=1/5$，点变成 $(0.8,-0.4)$，就是图 11.5的那一步。

输出什么　目前最好点需要每轮多算一次函数值，好处是保证单调；加权平均点不用算函数值，只需累加向量。最后一点没有上述保证。图 11.7用递减步长 $\alpha^{(t)}=R/(G\sqrt{t+1})$ 比较三者，横轴是步数，三条曲线都在上界之下，最后一点在一条带内不断跳动，目前最好点和加权平均点则是稳定的。

11.1 次微分
11.2 次梯度方法
11.3 邻近方法
11.3.1 邻近映射
11.3.2 邻近点法
11.4 复合优化
11.5 光滑化
11.6 代理模型
11.7 本章小结

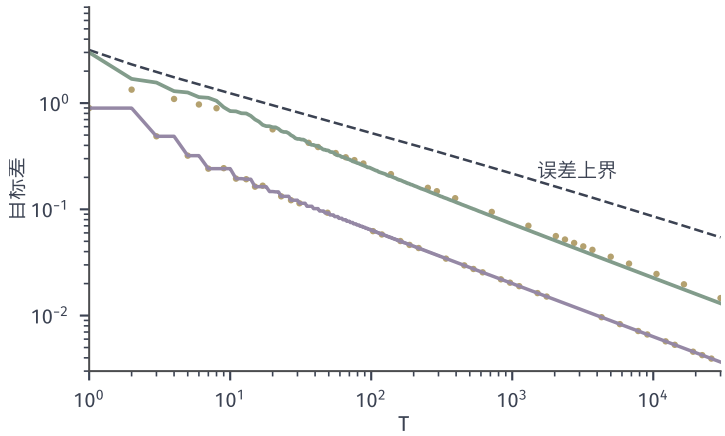


图 11.7 次梯度法的三种输出（双对数坐标）。目标是菱形目标，$\boldsymbol{x}^{(0)} = (1,1)$，步长 $\alpha^{(t)} = R/(G\sqrt{t+1})$。黄点是采样的最后点目标差，它随 t 的奇偶在一条带内跳动；绿线是加权平均点；紫线是目前最好点；黑色虚线是式 (11.19)的上界。

为什么慢，以及慢到什么程度 要达到目标差 ε，由式 (11.20)需要 $T \geq R^2G^2/\varepsilon^2$ 步。精度提高十倍，步数增加一百倍。梯度下降在光滑凸目标上的步数是 $O(1/\varepsilon)$，这里慢了一个量级。

这不是分析得不够细。只通过函数值和次梯度了解目标的方法，在维数足够大时存在最坏的函数，使任何这类方法在前若干步的目标差都不低于 $RG/(2(1+\sqrt{T}))$ 这样的量级，所以 $RG/\sqrt{T}$ 在黑箱模型下不能本质改进。这个下界的证明需要构造一族对抗性函数，篇幅较长，这里只用它的含义：要比 $1/\sqrt{T}$ 更快，就不能只靠黑箱，必须用上目标的结构。

次梯度法的优势在于通用和便宜：每步只要一个次梯度，存储一个向量，不需要光滑性和邻近映射。后面几节的方法都要求多知道一些东西。

11.3 邻近方法

次梯度法慢，一个原因是它在尖点上只用了一个斜率，把“这里是尖的”这个信息丢了。这就需要回答：如果愿意在每一步多做一点计算，怎样把尖点的结构保留在更新里？办法是把一步更新本身写成一个小优化问题。

11.3.1 邻近映射

梯度步有一个等价的写法：对光滑的 f，$\boldsymbol{x} - \alpha\nabla f(\boldsymbol{x})$ 是下面二次函数的最小点，

$$f(\boldsymbol{x}) + \langle \nabla f(\boldsymbol{x}), \boldsymbol{y} - \boldsymbol{x} \rangle + \frac{1}{2\alpha}\|\boldsymbol{y} - \boldsymbol{x}\|_2^2.$$

这里 f 被它的一阶近似代替，再加一个二次距离项，防止走太远。如果 f 的结构足够简单，就不必做一阶近似，直接把 f 本身留在问题里。

定义 11.7 邻近映射 设 $f:\mathbb{R}^n\to\mathbb{R}\cup\{+\infty\}$ 是适当、下半连续的凸函数，$\alpha>0$。输入点 $\boldsymbol{x}$ 的邻近映射（proximal mapping）定义为

$$\operatorname{prox}_{\alpha f}(\boldsymbol{x})=\arg\min_{\boldsymbol{y}\in\mathbb{R}^n}\Big\{f(\boldsymbol{y})+\frac{1}{2\alpha}\|\boldsymbol{y}-\boldsymbol{x}\|_2^2\Big\}. \tag{11.22}$$

括号里两项在拉锯：f 想让 $\boldsymbol{y}$ 去函数值低的地方，距离项想让 $\boldsymbol{y}$ 留在 $\boldsymbol{x}$ 附近，α 决定谁的话更算数。α 很小时，结果几乎停在 $\boldsymbol{x}$；α 很大时，结果接近 f 的最小点。

图 11.8对 $f(y)=|y|$，$\alpha=1$ 画出了这种拉锯。输入 $x=2$ 时，和函数的最小点在 $p=1$ 处，函数值的下降抵得过距离的代价。输入 $x=0.6$ 时，绿色曲线的最小点卡在 $y=0$ 的尖点上：再靠近 x 的收益太小，推不动尖点。

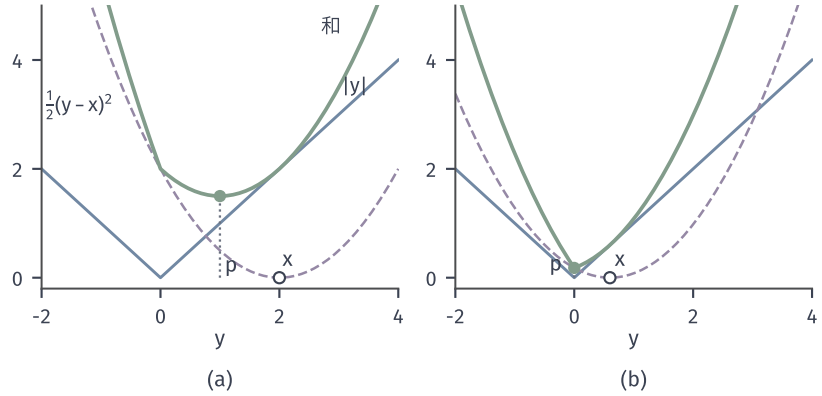


图 11.8 邻近映射是一个小优化问题，$f(y)=|y|$，$\alpha=1$。蓝线是 f，紫色虚线是距离项 $\frac{1}{2}(y-x)^2$，绿线是两者之和，绿点是和的最小点 p，空心圆是输入点。(a)$x=2$，最小点 $p=1$ 位于光滑部分。(b)$x=0.6$，最小点落在尖点 $p=0$ 上。

定义中对 f 的要求，下面的定理逐一用到。

定理 11.8 邻近映射的存在、唯一与刻画 设 f 是适当、下半连续的凸函数，$\alpha>0$。则对每个 $\boldsymbol{x}$，式 (11.22)有唯一的最小点 $\boldsymbol{p}$，并且

$$\boldsymbol{p}=\operatorname{prox}_{\alpha f}(\boldsymbol{x})\quad\Longleftrightarrow\quad\frac{\boldsymbol{x}-\boldsymbol{p}}{\alpha}\in\partial f(\boldsymbol{p}). \tag{11.23}$$

此外，映射是非扩张的：对任意 $\boldsymbol{x},\boldsymbol{y}$，记 $\boldsymbol{p}=\operatorname{prox}_{\alpha f}(\boldsymbol{x})$，$\boldsymbol{q}=\operatorname{prox}_{\alpha f}(\boldsymbol{y})$，有

$$\|\boldsymbol{p}-\boldsymbol{q}\|_2^2\le\langle\boldsymbol{p}-\boldsymbol{q},\boldsymbol{x}-\boldsymbol{y}\rangle\le\|\boldsymbol{x}-\boldsymbol{y}\|_2\|\boldsymbol{p}-\boldsymbol{q}\|_2. \tag{11.24}$$

证明 记子问题的目标为

$$\phi(\boldsymbol{y}) = f(\boldsymbol{y}) + \frac{1}{2\alpha}\|\boldsymbol{y}-\boldsymbol{x}\|_2^2.$$

存在性。适当、下半连续的凸函数有一个仿射下界（上图是闭凸集，用分离定理得到），设 $f(\boldsymbol{y}) \ge a + \langle \boldsymbol{b}, \boldsymbol{y}\rangle$。于是

$$\phi(\boldsymbol{y}) \ge a + \langle \boldsymbol{b}, \boldsymbol{y}\rangle + \frac{1}{2\alpha}\|\boldsymbol{y}-\boldsymbol{x}\|_2^2 \to +\infty \qquad (\|\boldsymbol{y}\|_2 \to \infty).$$

所以 ϕ 的下水平集有界。由第 1章的结果，下半连续性保证下水平集闭，下水平集紧时最小点存在。

唯一性。ϕ 是凸函数与严格凸的二次项之和，严格凸，严格凸函数至多有一个最小点。

刻画。距离项在全空间有限且可微，和规则取等号，由定理 11.4，

$$\boldsymbol{p} \text{ 是最小点} \quad\Longleftrightarrow\quad \boldsymbol{0} \in \partial f(\boldsymbol{p}) + \frac{\boldsymbol{p}-\boldsymbol{x}}{\alpha}.$$

移项即得式 (11.23)。

非扩张性。由式 (11.23)，

$$\boldsymbol{s} = \frac{\boldsymbol{x}-\boldsymbol{p}}{\alpha} \in \partial f(\boldsymbol{p}), \qquad \boldsymbol{v} = \frac{\boldsymbol{y}-\boldsymbol{q}}{\alpha} \in \partial f(\boldsymbol{q}).$$

两条支撑不等式

$$f(\boldsymbol{q}) \ge f(\boldsymbol{p}) + \langle \boldsymbol{s}, \boldsymbol{q}-\boldsymbol{p}\rangle, \qquad f(\boldsymbol{p}) \ge f(\boldsymbol{q}) + \langle \boldsymbol{v}, \boldsymbol{p}-\boldsymbol{q}\rangle$$

相加，得到次微分的单调性 $\langle \boldsymbol{s}-\boldsymbol{v}, \boldsymbol{p}-\boldsymbol{q}\rangle \ge 0$。代入 $\boldsymbol{s}, \boldsymbol{v}$ 的表达式并整理，

$$\langle (\boldsymbol{x}-\boldsymbol{y}) - (\boldsymbol{p}-\boldsymbol{q}), \boldsymbol{p}-\boldsymbol{q}\rangle \ge 0.$$

这就是式 (11.24)的左半，右半是 Cauchy 不等式。 ■

每个条件都有用处。下半连续保证最小点取得，例如 f 在 $(0,1)$ 内为 0、其余为 $+\infty$ 时，$\operatorname{dom} f$ 不闭，$\boldsymbol{x}=2$ 的最小点取不到。凸性保证唯一和式 (11.23)。若 $f=-|y|$，$\alpha=1$，$x=0$，$y=\pm 1$ 都是最小点，映射不再是单值的。

显式步与隐式步 把式 (11.23)写成迭代的样子：

$$\boldsymbol{x}^+ = \boldsymbol{x} - \alpha \boldsymbol{s}, \qquad \boldsymbol{s} \in \partial f(\boldsymbol{x}^+). \tag{11.25}$$

形式与次梯度步一样，差别在于斜率取在新点上。显式步先读斜率再走，隐式步要求“走到的地方的斜率正好解释这一步”。由于 $\boldsymbol{x}^+$ 事先未知，这是一个隐式方程，邻近映射就是它的解。

隐式的好处看两个例子。图 11.9(a) 用 $f(x)=|x|$，$x^{(0)}=1$，$\alpha=0.4$。次梯度步的斜率总是 ±1，所以点按 0.4 的步子走过零点来回跳，序列是 1, 0.6, 0.2, −0.2, 0.2, ...；邻近步在前两步相同，第三步由式 (11.25)选出 $s=0.5\in[-1,1]$，恰好落在零上并停住，序列是 1, 0.6, 0.2, 0, 0, ...。

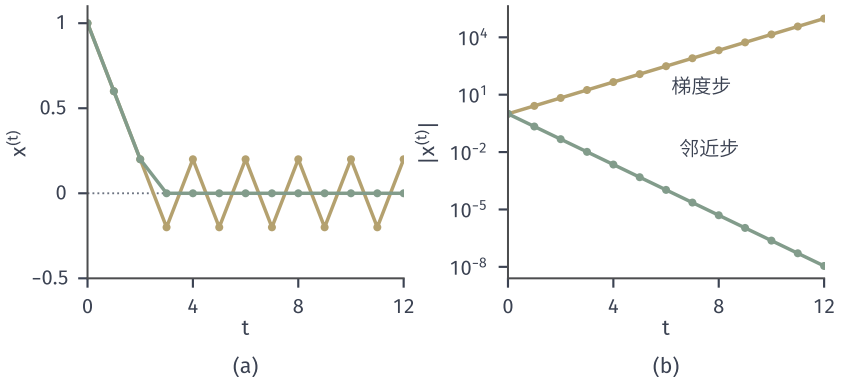


图 11.9　显式步（黄）与隐式的邻近步（绿）。$\alpha=0.4$，$x^{(0)}=1$。(a)$f(x)=|x|$：次梯度步在零点两侧反复跳动，邻近步第三步后停在零。(b)$f(x)=\frac{9}{2}x^2$：α 超过 $2/L=2/9$，梯度步发散，邻近步对任何 $\alpha>0$ 都收缩，纵轴为对数坐标。

第二个例子是二次函数 $f(x)=\frac{c}{2}x^2$，$c=9$。显式与隐式的结果分别是

$$x^+=(1-\alpha c)x,\qquad x^+=\frac{x}{1+\alpha c}.$$

$\alpha=0.4$ 时前者的放大倍数 $|1-3.6|=2.6$，发散；后者的倍数 $1/4.6$，收缩。隐式步对任意 $\alpha>0$ 都不会过冲，见图 11.9(b)。代价已经写在公式里：αc 大时要解一个方程，只不过一元时解起来很便宜。表 11.2对比了两者。

	显式的梯度或次梯度步	隐式的邻近步
更新	$\boldsymbol{x}^+=\boldsymbol{x}-\alpha\boldsymbol{g}(\boldsymbol{x})$	$\boldsymbol{x}^+=\boldsymbol{x}-\alpha\boldsymbol{s}$，$\boldsymbol{s}\in\partial f(\boldsymbol{x}^+)$
步长限制	光滑时 $\alpha<2/L$	任意 $\alpha>0$
尖点	跨过去，来回振荡	可以停在尖点上
每步代价	一次梯度或次梯度	解一个带二次项的子问题
是否下降	非光滑时不一定	总是下降（或已最优）

表 11.2　显式步与隐式的邻近步。两者的数学形式相同，差别在于斜率取在哪个点上。

第一个例子：投影 设 $\boldsymbol{C}$ 是非空闭凸集，$f = \iota_{\boldsymbol{C}}$。约束指标函数在 $\boldsymbol{C}$ 内为零，外面为 $+\infty$，邻近子问题变成在 $\boldsymbol{C}$ 里找离 $\boldsymbol{x}$ 最近的点：

$$\operatorname{prox}_{\alpha\iota_{\boldsymbol{C}}}(\boldsymbol{x}) = \Pi_{\boldsymbol{C}}(\boldsymbol{x}) = \arg\min_{\boldsymbol{y}\in\boldsymbol{C}} \|\boldsymbol{y}-\boldsymbol{x}\|_2. \tag{11.26}$$

结果与 α 无关，因为函数值在 $\boldsymbol{C}$ 内恒为零。这里 $\iota_{\boldsymbol{C}}$ 适当、下半连续、凸的条件，正好要求 $\boldsymbol{C}$ 非空、闭、凸。

由式 (11.23)和式 (11.13)，$\boldsymbol{p} = \Pi_{\boldsymbol{C}}(\boldsymbol{x})$ 的特征是

$$\langle \boldsymbol{x}-\boldsymbol{p}, \boldsymbol{y}-\boldsymbol{p}\rangle \le 0 \qquad \text{对所有 } \boldsymbol{y}\in\boldsymbol{C}.$$

也就是从 $\boldsymbol{p}$ 看，$\boldsymbol{x}$ 与 $\boldsymbol{C}$ 中任一点的夹角不小于直角。

投影是否好算取决于 $\boldsymbol{C}$。盒子逐坐标截断，球沿半径缩回。例如 $\boldsymbol{C} = [-1,1]^2$ 时，$(2, 0.5)$ 投影到 $(1, 0.5)$；单位球时，$(3, 4)$ 投影到 $(0.6, 0.8)$。图 11.10画出了这两种情形。

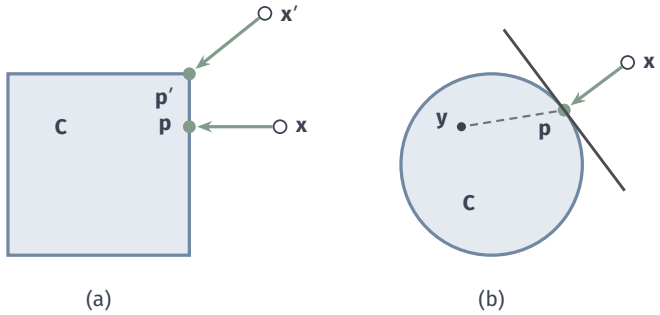


图 11.10 投影是约束指标函数的邻近映射。浅蓝区域是 $\boldsymbol{C}$，空心圆是输入点，绿点是投影。(a) 盒约束逐坐标截断，$\boldsymbol{x}'$ 落在角上。(b) 球约束，深灰线是过 $\boldsymbol{p}$ 的切线。集合内任一点 $\boldsymbol{y}$ 都在切线的同一侧，从 $\boldsymbol{p}$ 看 $\boldsymbol{x}$ 与 $\boldsymbol{y}$ 夹角不小于直角。

第二个例子：软阈值 取 $f(y) = |y|$。由式 (11.23)和式 (11.5)，按 p 的符号分三种情形。

若 $p > 0$，则 $(x-p)/\alpha = 1$，即 $p = x - \alpha$，这要求 $x > \alpha$。

若 $p < 0$，则 $(x-p)/\alpha = -1$，即 $p = x + \alpha$，这要求 $x < -\alpha$。

若 $p = 0$，则 $x/\alpha \in [-1, 1]$，即 $|x| \le \alpha$。

三种情形恰好互斥且覆盖全部 x，合起来得到**软阈值** (soft thresholding) 算子：

$$S_\alpha(x) = \operatorname{prox}_{\alpha|\cdot|}(x) = \operatorname{sign}(x)\max\{|x| - \alpha, 0\}. \tag{11.27}$$

它把靠近零的输入压成零，把其余的朝零移动 α。向量的 ℓ_1 范数按坐标可分，邻近映射就是逐坐标软阈值。阈值由步长乘系数给出，$\alpha\lambda\|\cdot\|_1$ 的

11.1 次微分
11.2 次梯度方法
11.3 邻近方法
11.3.1 邻近映射
11.3.2 邻近点法
11.4 复合优化
11.5 光滑化
11.6 代理模型
11.7 本章小结

邻近映射就是逐坐标作用的 $S_{\alpha\lambda}$。图 11.8的两个输入，由公式得 $S_1(2)=1$，$S_1(0.6)=0$，都与图中相符。

图 11.11(a) 是这个映射的图像，粗线的长度 2α 就是原点次微分的长度 2 乘 α。这条规律具有一般性。(b) 是三段折线在 $\alpha=1$ 的邻近映射，用同样的分情形方法，每个分支上 $p=x-\alpha a_i$（a_i 是斜率），两个尖点各对应一段水平线，长度分别是 α 乘 $\frac{3}{2}$（$x\in[-1,\frac{1}{2}]$）和 α 乘 $\frac{3}{2}$（$x\in[\frac{5}{2},4]$），正好是 $\partial f(0)$ 和 $\partial f(2)$ 的长度乘 α。

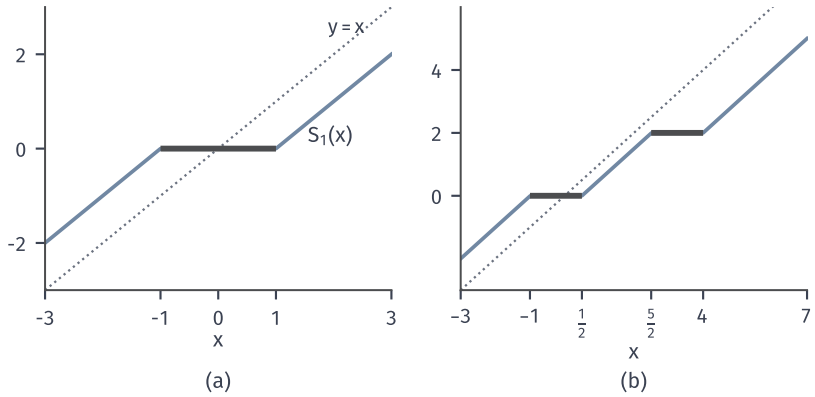


图 11.11　两个邻近映射的图像（$\alpha=1$），点线是恒等映射。(a) 软阈值 S_1，深灰粗线是被压成零的区间 $[-1,1]$。(b) 三段折线的邻近映射，深灰粗线是落在尖点 $x=0$ 和 $x=2$ 上的输入区间，长度等于对应次微分的长度乘 α。

11.3.2 邻近点法

既然邻近映射把点往 f 低的方向移，反复应用它会怎样？**邻近点法**（proximal point method）就是

$$\boldsymbol{x}^{(t+1)}=\operatorname{prox}_{\alpha^{(t)}f}(\boldsymbol{x}^{(t)}),\qquad \alpha^{(t)}>0. \tag{11.28}$$

这是把式 (11.25)反复迭代，每一步的位移除以步长都是新点的一个次梯度。下面的定理说明步长可以任意大，这是显式方法做不到的。

定理 11.9　邻近点法的目标差界　设 f 是适当、下半连续的凸函数，存在最小点 $\boldsymbol{x}^\star$，每一步精确计算式 (11.28)。则 $f(\boldsymbol{x}^{(t)})$ 单调不增，并且

$$f(\boldsymbol{x}^{(T)})-f^\star\le\frac{\|\boldsymbol{x}^{(0)}-\boldsymbol{x}^\star\|_2^2}{2\sum_{t=0}^{T-1}\alpha^{(t)}}. \tag{11.29}$$

证明 省略上标，把第 t 步的点、新点和步长写成 $\boldsymbol{x}, \boldsymbol{x}^{+}, \alpha$。由式 (11.23)，向量 $(\boldsymbol{x}-\boldsymbol{x}^{+})/\alpha$（记为 $\boldsymbol{s}$）是 f 在 $\boldsymbol{x}^{+}$ 的次梯度，所以对任意 $\boldsymbol{z}$，

$$f(\boldsymbol{x}^{+}) - f(\boldsymbol{z}) \le \langle \boldsymbol{s}, \boldsymbol{x}^{+} - \boldsymbol{z} \rangle = \frac{1}{\alpha}\langle \boldsymbol{x} - \boldsymbol{x}^{+}, \boldsymbol{x}^{+} - \boldsymbol{z} \rangle.$$

取 $\boldsymbol{z} = \boldsymbol{x}$，右端是 $-\|\boldsymbol{x}^{+} - \boldsymbol{x}\|_2^2/\alpha \le 0$，单调性得证。

取 $\boldsymbol{z} = \boldsymbol{x}^{\star}$，并使用恒等式

$$2\langle \boldsymbol{a}-\boldsymbol{b}, \boldsymbol{b}-\boldsymbol{c} \rangle = \|\boldsymbol{a}-\boldsymbol{c}\|_2^2 - \|\boldsymbol{b}-\boldsymbol{c}\|_2^2 - \|\boldsymbol{a}-\boldsymbol{b}\|_2^2, \tag{11.30}$$

得到

$$\alpha\big(f(\boldsymbol{x}^{+}) - f^{\star}\big) \le \frac{1}{2}\Big(\|\boldsymbol{x}-\boldsymbol{x}^{\star}\|_2^2 - \|\boldsymbol{x}^{+}-\boldsymbol{x}^{\star}\|_2^2\Big).$$

对 $t = 0, \dots, T-1$ 相加，距离项相消，右端不超过 $\|\boldsymbol{x}^{(0)} - \boldsymbol{x}^{\star}\|_2^2/2$。左端由单调性，每一项的 $f(\boldsymbol{x}^{(t+1)}) \ge f(\boldsymbol{x}^{(T)})$，于是

$$\Big(\sum_{t=0}^{T-1} \alpha^{(t)}\Big)\big(f(\boldsymbol{x}^{(T)}) - f^{\star}\big) \le \frac{1}{2}\|\boldsymbol{x}^{(0)} - \boldsymbol{x}^{\star}\|_2^2.$$

两边相除即得。 ■

分母里是 $\alpha^{(t)}$ 的累积，所以 α 越大收敛越快。一步用很大的 α，子问题几乎就是原问题，这正是问题所在：式 (11.28)把难度搬进了子问题，并没有消除它。

用第 6章的二次目标 $f(\boldsymbol{x}) = \frac{1}{2}(x_1^2 + 9x_2^2)$，$\boldsymbol{x}^{(0)} = (9, 1)$ 演示。对角情形的子问题有闭式解，$\alpha = 1$ 时第一步是

$$\boldsymbol{x}^{(1)} = \Big(\frac{9}{1+1}, \frac{1}{1+9}\Big) = (4.5,\ 0.1).$$

再走一步，

$$\boldsymbol{x}^{(2)} = (2.25,\ 0.01).$$

图 11.12(a) 中绿色路径没有梯度下降（黄色，$\alpha = 1/5$）的折返，(b) 说明 α 增大时收敛更快。这个例子每步的工作量几乎为零，但只是因为 $\boldsymbol{H}$ 是对角矩阵。一般二次目标的子问题是线性方程组 $(\boldsymbol{I} + \alpha\boldsymbol{H})\boldsymbol{x}^{+} = \boldsymbol{x}$，$\alpha$ 越大，它的条件数越接近 $\boldsymbol{H}$ 本身，求解代价越接近原问题。

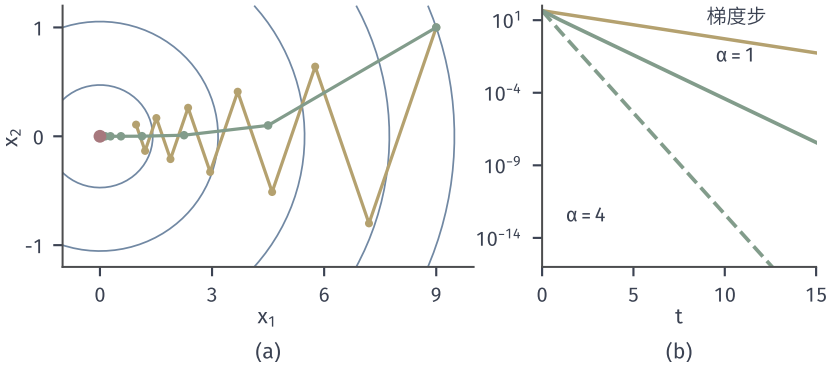


图 11.12 邻近点法在二次目标 $\frac{1}{2}(x_1^2 + 9x_2^2)$ 上的表现，$\boldsymbol{x}^{(0)} = (9, 1)$。(a) 等高线（蓝）上的路径，横纵比例不同，绿色为 $\alpha = 1$ 的邻近点法，黄色为 $\alpha = 1/5$ 的梯度下降。(b) 目标差（对数坐标），绿色实线、虚线分别是 $\alpha = 1, 4$ 的邻近点法，黄色是梯度下降。

三件事要分别核验 使用邻近点法时要分清三个问题，它们不能相互代替。

第一，映射可定义。这由定理 11.8回答，只要 f 适当、下半连续、凸。

第二，子问题可计算。定义合法不等于算得出来。对 $|x|$ 有闭式解，对 $\frac{1}{2}(x_1^2 + 9x_2^2)$ 有简单公式；对一般的 f，子问题本身需要迭代求解。

第三，原问题收敛。定理 11.9额外要求最小点存在。取 $f(x) = e^x$，邻近映射处处有定义，每一步也能用牛顿法算出。$\alpha = 1$，$x^{(0)} = 0$ 时，方程 $p - x + e^p = 0$ 依次给出

$$x^{(1)} \approx -0.567, \qquad x^{(2)} \approx -0.953, \qquad x^{(3)} \approx -1.242.$$

序列单调趋于 $-\infty$，$f(x^{(t)})$ 趋于下确界 0，但下确界取不到，也就不存在“收敛到解”这回事。

子问题的精度 实际中子问题只能算到一定精度。设计算结果与精确的邻近点的距离不超过 $\varepsilon^{(t)}$。由非扩张性 (11.24)，$\boldsymbol{x}^\star$ 是不动点，所以

$$\|\boldsymbol{x}^{(t+1)} - \boldsymbol{x}^\star\|_2 \le \|\boldsymbol{x}^{(t)} - \boldsymbol{x}^\star\|_2 + \varepsilon^{(t)}. \tag{11.31}$$

只要 $\sum_t \varepsilon^{(t)} < \infty$，这个递推就说明序列有界，误差的累积不会把点推走。进一步可证，在 $\alpha^{(t)}$ 有正下界时序列收敛到一个最小点，证明要用到不动点序列的单调性论证，篇幅较长。

若误差不衰减，结果只能到某个精度。用 $f(x) = |x|$，$\alpha = 0.4$，$x^{(0)} = 1$，假设每一步都多偏出 0.1：

$$1 \to 0.7 \to 0.4 \to 0.1 \to 0.1 \to \cdots$$

11.1 次微分
11.2 次梯度方法
11.3 邻近方法
11.4 复合优化
11.4.1 邻近梯度法
11.4.2 加速邻近梯度法（FISTA）
11.4.3 停止条件与计算成本
11.5 光滑化
11.6 代理模型
11.7 本章小结

序列停在 0.1。这里的 0.1 恰好是子问题的误差。把误差取成 $\varepsilon^{(t)} = 0.1 \cdot 2^{-t}$ 后，点最终收敛到零。子问题要算多准，取决于最后想要多准，二者是同一量级的问题，这个经验在后面的邻近梯度法上同样适用。

11.4 复合优化

Lasso 的目标一半是光滑的最小二乘，一半是带尖点的 ℓ_1 范数。对整个目标用次梯度法，浪费了光滑项的信息；对整个目标用邻近点法，子问题和原问题一样难。能否只线性化光滑的一半，把有尖点的一半原样留下，并得到比次梯度法快得多的保证？

考虑**复合目标**（composite objective）

$$F(\boldsymbol{x}) = f(\boldsymbol{x}) + r(\boldsymbol{x}), \tag{11.32}$$

其中 $f : \mathbb{R}^n \to \mathbb{R}$ 可微且梯度 L-Lipschitz 连续，r 是适当、下半连续的凸函数，并且 $\operatorname{prox}_{\alpha r}$ 容易计算。计算上的约定是：读 ∇f 和计算 $\operatorname{prox}_{\alpha r}$ 都可以负担，但对 $f + r$ 整体的邻近映射算不了。

11.4.1 邻近梯度法

主要思想 由第 5章的下降引理，当 $0 < \alpha \le 1/L$ 时，光滑项有二次上界

$$f(\boldsymbol{y}) \le f(\boldsymbol{x}) + \langle \nabla f(\boldsymbol{x}), \boldsymbol{y} - \boldsymbol{x} \rangle + \frac{1}{2\alpha} \|\boldsymbol{y} - \boldsymbol{x}\|_2^2.$$

把 F 中的 f 换成这个上界，r 一字不动，得到当前点 $\boldsymbol{x}^{(t)}$ 处的模型：

$$m^{(t)}(\boldsymbol{y}) = f(\boldsymbol{x}^{(t)}) + \langle \nabla f(\boldsymbol{x}^{(t)}), \boldsymbol{y} - \boldsymbol{x}^{(t)} \rangle + \frac{1}{2\alpha} \|\boldsymbol{y} - \boldsymbol{x}^{(t)}\|_2^2 + r(\boldsymbol{y}). \tag{11.33}$$

模型中与 $\boldsymbol{y}$ 有关的一次项和二次项可以配方：

$$\langle \nabla f(\boldsymbol{x}), \boldsymbol{y} - \boldsymbol{x} \rangle + \frac{1}{2\alpha} \|\boldsymbol{y} - \boldsymbol{x}\|_2^2 = \frac{1}{2\alpha} \left\| \boldsymbol{y} - \left(\boldsymbol{x} - \alpha \nabla f(\boldsymbol{x})\right) \right\|_2^2 - \frac{\alpha}{2} \|\nabla f(\boldsymbol{x})\|_2^2.$$

去掉不含 $\boldsymbol{y}$ 的项，模型的最小点就是从梯度步的终点出发求 r 的邻近映射。这就是**邻近梯度法**（proximal gradient method）：

$$\boldsymbol{x}^{(t+1)} = \operatorname{prox}_{\alpha r}\left(\boldsymbol{x}^{(t)} - \alpha \nabla f(\boldsymbol{x}^{(t)})\right). \tag{11.34}$$

它分两步看：光滑项做显式的梯度步，非光滑项做隐式的邻近步。图 11.13用一维的 $F(x) = \frac{1}{2}(x-2)^2 + \frac{1}{2}|x|$（$L = 1$）展示模型的作用。绿色虚线在原点处有与 F 相同的尖点，这是把 r 留在模型里的直接效果。(a) 的 $\alpha = 0.5 \le 1/L$，模型处处高于 F，最小化模型一定使 F 下降，这与第 5章

的下降引理是同一个道理。(b) 的 $\alpha = 2.5 > 1/L$，模型不再是上界，它的最小点跑到了 F 更高的地方。

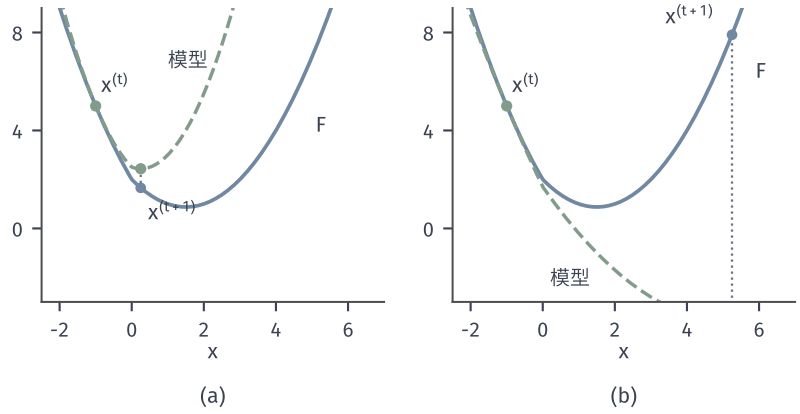


图 11.13 复合目标的局部模型，$F(x) = \frac{1}{2}(x-2)^2 + \frac{1}{2}|x|$，$L = 1$，当前点 $x^{(t)} = -1$。蓝线是 F，绿色虚线是式 (11.33)的模型，蓝点是新点处的真实目标值。(a)$\alpha = 0.5$，模型在 F 上方，新点 $x^{(t+1)} = 0.25$ 处 F 从 5 降到约 1.66。(b)$\alpha = 2.5$，模型部分低于 F，新点 $x^{(t+1)} = 5.25$ 处 F 升到约 7.9。

式 (11.34)包含几种已知情形：$r = 0$ 时是梯度下降；$f = 0$ 时是邻近点法；$r = \iota_C$ 时是投影梯度法，集合的计算和可行点的最优性将在第 21章讨论。

取 $r = \lambda\|\cdot\|_1$（$\lambda > 0$），f 为 Lasso 的最小二乘项，$\nabla f(\boldsymbol{x}) = \boldsymbol{A}^\top(\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b})$，$L = \|\boldsymbol{A}\|_2^2$。由软阈值式 (11.27)，邻近步的阈值是步长乘 λ，式 (11.34)成为

$$\boldsymbol{x}^{(t+1)} = S_{\alpha\lambda}\big(\boldsymbol{x}^{(t)} - \alpha\boldsymbol{A}^\top(\boldsymbol{A}\boldsymbol{x}^{(t)} - \boldsymbol{b})\big). \tag{11.35}$$

这种迭代称为**迭代软阈值算法**（iterative shrinkage-thresholding algorithm，ISTA）。“迭代”和“阈值”正好是它的两步：先按最小二乘的方向修正系数，再把小的系数压成零。

计算过程 用章首的例 (11.1)。

变量

- $\boldsymbol{A} \in \mathbb{R}^{p\times n}$，$\boldsymbol{b} \in \mathbb{R}^p$，$\lambda > 0$：数据。例中 $p = 3$，$n = 2$，$\lambda = 1$。
- $\boldsymbol{x}^{(t)} \in \mathbb{R}^n$：当前点。
- $\boldsymbol{g}^{(t)}$：光滑项在当前点的梯度。
- α：步长，$\alpha \le 1/L$。

初始化 选 $\boldsymbol{x}^{(0)}$ 和 α。例中 $\boldsymbol{A}^{\top}\boldsymbol{A}$ 和 $\boldsymbol{A}^{\top}\boldsymbol{b}$ 分别是

$$\boldsymbol{A}^{\top}\boldsymbol{A} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}, \qquad \boldsymbol{A}^{\top}\boldsymbol{b} = \begin{pmatrix} 5 \\ 2 \end{pmatrix}.$$

$\boldsymbol{A}^{\top}\boldsymbol{A}$ 的特征值是 3 和 1，所以 $L = 3$。取 $\alpha = 1/3$，$\boldsymbol{x}^{(0)} = (0, 0)$，阈值 $\alpha\lambda = 1/3$。

每轮更新

1. 算梯度，$\boldsymbol{g}^{(t)}$ 等于 $\boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{x}^{(t)}$ 减去 $\boldsymbol{A}^{\top}\boldsymbol{b}$。例中第一轮

$$\boldsymbol{g}^{(0)} = (-5, -2).$$

2. 走梯度步 $\boldsymbol{z}^{(t)} = \boldsymbol{x}^{(t)} - \alpha\boldsymbol{g}^{(t)}$。例中第一轮

$$\boldsymbol{z}^{(0)} = \left(\frac{5}{3},\ \frac{2}{3}\right).$$

3. 逐坐标软阈值，由式 (11.35)得新点。例中第一轮

$$\boldsymbol{x}^{(1)} = \left(\frac{4}{3},\ \frac{1}{3}\right), \qquad F(\boldsymbol{x}^{(1)}) = \frac{11}{3}.$$

第二轮的三个量依次是

$$\boldsymbol{g}^{(1)} = (-2,\ 0), \qquad \boldsymbol{z}^{(1)} = \left(2,\ \frac{1}{3}\right), \qquad \boldsymbol{x}^{(2)} = \left(\frac{5}{3},\ 0\right).$$

第二分量恰好被压到零。第三轮的三个量依次是

$$\boldsymbol{g}^{(2)} = \left(-\frac{5}{3}, -\frac{1}{3}\right), \qquad \boldsymbol{z}^{(2)} = \left(\frac{20}{9},\ \frac{1}{9}\right), \qquad \boldsymbol{x}^{(3)} = \left(\frac{17}{9},\ 0\right).$$

此后第二分量一直为零：$\boldsymbol{z}$ 的第二分量是 $(2 - x_1)/3$，绝对值小于阈值 $1/3$。第一分量满足 $x_1^{+} = x_1/3 + 4/3$，每轮把与 2 的距离缩小三分之一。目标差依次是

$$\frac{2}{3}, \qquad \frac{1}{9}, \qquad \frac{1}{81}, \qquad \frac{1}{729}, \cdots$$

达到预定的迭代次数或后面第 11.4.3小节的停止条件后结束，最终得到 $\boldsymbol{x}^{(T)} \to (2, 0)$，也就是第 11.1节验证的解。

收敛分析 分析的核心是一步不等式，把式 (11.23)与下降引理结合。

引理 11.10　邻近梯度的一步不等式　设 f 凸且可微，r 是适当、下半连续的凸函数，$F = f + r$。给定 $\boldsymbol{y}$ 与 $\alpha > 0$，令

$$\boldsymbol{x}^+ = \operatorname{prox}_{\alpha r}\big(\boldsymbol{y} - \alpha \nabla f(\boldsymbol{y})\big). \tag{11.36}$$

若

$$f(\boldsymbol{x}^+) \le f(\boldsymbol{y}) + \langle \nabla f(\boldsymbol{y}), \boldsymbol{x}^+ - \boldsymbol{y}\rangle + \frac{1}{2\alpha}\|\boldsymbol{x}^+ - \boldsymbol{y}\|_2^2, \tag{11.37}$$

则对任意 $\boldsymbol{z} \in \operatorname{dom} F$，

$$F(\boldsymbol{x}^+) - F(\boldsymbol{z}) \le \frac{1}{2\alpha}\Big(\|\boldsymbol{y} - \boldsymbol{z}\|_2^2 - \|\boldsymbol{x}^+ - \boldsymbol{z}\|_2^2\Big). \tag{11.38}$$

证明　f 的凸性给出下界

$$f(\boldsymbol{y}) + \langle \nabla f(\boldsymbol{y}), \boldsymbol{z} - \boldsymbol{y}\rangle \le f(\boldsymbol{z}).$$

把它代入式 (11.37)，

$$f(\boldsymbol{x}^+) \le f(\boldsymbol{z}) + \langle \nabla f(\boldsymbol{y}), \boldsymbol{x}^+ - \boldsymbol{z}\rangle + \frac{1}{2\alpha}\|\boldsymbol{x}^+ - \boldsymbol{y}\|_2^2.$$

由式 (11.23)和式 (11.36)，下面的 $\boldsymbol{s}$ 是 r 在 $\boldsymbol{x}^+$ 的次梯度：

$$\boldsymbol{s} = \frac{\boldsymbol{y} - \boldsymbol{x}^+}{\alpha} - \nabla f(\boldsymbol{y}).$$

所以

$$r(\boldsymbol{x}^+) \le r(\boldsymbol{z}) + \langle \boldsymbol{s}, \boldsymbol{x}^+ - \boldsymbol{z}\rangle.$$

两式相加，$\nabla f(\boldsymbol{y})$ 的项相消，得到

$$F(\boldsymbol{x}^+) \le F(\boldsymbol{z}) + \frac{1}{\alpha}\langle \boldsymbol{y} - \boldsymbol{x}^+, \boldsymbol{x}^+ - \boldsymbol{z}\rangle + \frac{1}{2\alpha}\|\boldsymbol{x}^+ - \boldsymbol{y}\|_2^2.$$

再用恒等式 (11.30)，令 $\boldsymbol{a} = \boldsymbol{y}$，$\boldsymbol{b} = \boldsymbol{x}^+$，$\boldsymbol{c} = \boldsymbol{z}$，最后一项被抵消，就是式 (11.38)。 ■

条件 (11.37)只在 $\boldsymbol{y}$ 和 $\boldsymbol{x}^+$ 这一对点上要求上界成立，$\alpha \le 1/L$ 时自动满足。下面的结论就是这个引理对 $\boldsymbol{y} = \boldsymbol{x}^{(t)}$ 的累加。

11.1 次微分
11.2 次梯度方法
11.3 邻近方法
11.4 复合优化
11.4.1 邻近梯度法
11.4.2 加速邻近梯度法（FISTA）
11.4.3 停止条件与计算成本
11.5 光滑化
11.6 代理模型
11.7 本章小结

定理 11.11　邻近梯度法的收敛速率　设 f 凸，梯度 L-Lipschitz 连续，r 是适当、下半连续的凸函数，F 存在最小点 $\boldsymbol{x}^\star$，每步精确计算邻近映射，$0<\alpha\le 1/L$。则 $F(\boldsymbol{x}^{(t)})$ 单调不增，并且

$$F(\boldsymbol{x}^{(T)})-F^\star \le \frac{\|\boldsymbol{x}^{(0)}-\boldsymbol{x}^\star\|_2^2}{2\alpha T}. \tag{11.39}$$

证明　在式 (11.38)中取 $\boldsymbol{y}=\boldsymbol{z}=\boldsymbol{x}^{(t)}$（$t\ge 1$ 时 $\boldsymbol{x}^{(t)}\in\operatorname{dom}F$），右端为负，所以 F 单调不增。

取 $\boldsymbol{y}=\boldsymbol{x}^{(t)}$，$\boldsymbol{z}=\boldsymbol{x}^\star$，对 $t=0,\dots,T-1$ 相加，距离项相消，得到

$$\sum_{t=0}^{T-1}\bigl(F(\boldsymbol{x}^{(t+1)})-F^\star\bigr)\le\frac{\|\boldsymbol{x}^{(0)}-\boldsymbol{x}^\star\|_2^2}{2\alpha}.$$

由单调性，左端每一项都不小于 $F(\boldsymbol{x}^{(T)})-F^\star$，所以左端不小于 $T(F(\boldsymbol{x}^{(T)})-F^\star)$，即得式 (11.39)。 ■

速率 $O(1/T)$ 与第 6章的梯度下降相同，比次梯度法的 $O(1/\sqrt{T})$ 快得多，代价是 r 的邻近映射必须算得出。这里 $\boldsymbol{x}^{(0)}$ 若不在 $\operatorname{dom}r$，第一步的邻近映射会把点带入定义域，定理依然成立。

例中 $R^2=\|\boldsymbol{x}^{(0)}-\boldsymbol{x}^\star\|_2^2=4$，$\alpha=1/3$，界为 $6/T$，$T=3$ 时为 2。实际目标差 $1/81$ 小得多，因为一旦 x_2 落到零，迭代实际上在一维的强凸二次函数上运行，收敛是线性的。这也是 Lasso 上常见的现象：大多数轮次之后，支撑集（非零分量的位置）不再变化，算法此后近似一个定义在支撑集上的光滑问题。

11.4.2 加速邻近梯度法（FISTA）

第 6章的 Nesterov 方法把光滑凸目标的速率从 $1/T$ 提高到 $1/T^2$，代价只是多存一个向量。本小节要回答：这种外推能否直接搬到复合目标上？

主要思想　把 Nesterov 方法里的梯度步换成邻近梯度步，外推系数原样保留。这就是**加速邻近梯度法**（fast iterative shrinkage-thresholding algorithm, FISTA）[3]：

$$\begin{aligned}\boldsymbol{x}^{(t+1)}&=\operatorname{prox}_{\alpha r}\bigl(\boldsymbol{y}^{(t)}-\alpha\nabla f(\boldsymbol{y}^{(t)})\bigr),\\ \boldsymbol{y}^{(t+1)}&=\boldsymbol{x}^{(t+1)}+\frac{\theta^{(t)}-1}{\theta^{(t+1)}}\bigl(\boldsymbol{x}^{(t+1)}-\boldsymbol{x}^{(t)}\bigr).\end{aligned}\tag{11.40}$$

[3] A. Beck, M. Teboulle, *A Fast Iterative Shrinkage-Thresholding Algorithm for Linear Inverse Problems* In SIAM Journal on Imaging Sciences, 2009, vol. 2, no. 1, pp. 183–202

其中 $\boldsymbol{y}^{(0)} = \boldsymbol{x}^{(0)}$，$\theta^{(0)} = 1$，外推参数按第 6章的递推更新：

$$\theta^{(t+1)} = \frac{1 + \sqrt{1 + 4(\theta^{(t)})^2}}{2}. \tag{11.41}$$

图 11.14是一步的结构：先沿上一步位移外推到 $\boldsymbol{y}^{(t)}$，在外推点读梯度，再做邻近步。梯度必须取在 $\boldsymbol{y}^{(t)}$，这是 Nesterov 方法的特点，与重球法不同。

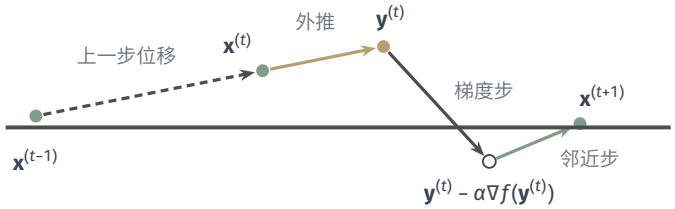


图 11.14　FISTA 的一步。黄色外推从 $\boldsymbol{x}^{(t)}$ 沿上一步位移（虚线）走到 $\boldsymbol{y}^{(t)}$，深灰箭头是在 $\boldsymbol{y}^{(t)}$ 处的梯度步，绿色箭头是邻近步，可能把点压回坐标面（深灰横线）。空心圆是梯度步的终点。

计算过程　仍用例 (11.1)，$\alpha = 1/3$，阈值 $1/3$。

变量

- $\boldsymbol{x}^{(t)}$：邻近步的输出，是算法报告的点。
- $\boldsymbol{y}^{(t)}$：外推点，形状与 $\boldsymbol{x}$ 相同，读梯度在这里。
- $\theta^{(t)}$：外推参数。

初始化　$\boldsymbol{x}^{(0)} = \boldsymbol{y}^{(0)} = \boldsymbol{0}$，$\theta^{(0)} = 1$。

每轮更新

1. 在 $\boldsymbol{y}^{(t)}$ 读梯度并做邻近梯度步，由式 (11.40)得 $\boldsymbol{x}^{(t+1)}$。例中第一轮 $\boldsymbol{y}^{(0)} = \boldsymbol{0}$，结果与 ISTA 相同：
$$\boldsymbol{x}^{(1)} = \left(\frac{4}{3},\ \frac{1}{3}\right).$$

2. 更新 $\theta^{(t+1)}$。例中第一轮
$$\theta^{(1)} = \frac{1 + \sqrt{5}}{2} \approx 1.618.$$

3. 计算外推点。例中第一轮系数 $(\theta^{(0)} - 1)/\theta^{(1)} = 0$，所以 $\boldsymbol{y}^{(1)} = \boldsymbol{x}^{(1)}$。

   第二轮仍无外推差别，同样得到 $\boldsymbol{x}^{(2)} = (5/3, 0)$。这时开始用上外推，
$$\theta^{(2)} \approx 2.194, \qquad \frac{\theta^{(1)} - 1}{\theta^{(2)}} \approx 0.282.$$

外推点是

$$\boldsymbol{y}^{(2)} = \Big(\frac{5}{3}, 0\Big) + 0.282\Big(\frac{1}{3}, -\frac{1}{3}\Big) \approx (1.761,\ -0.094).$$

第三轮的梯度、梯度步和新点依次是

$$\nabla f(\boldsymbol{y}^{(2)}) \approx (-1.573,\ -0.427), \qquad \boldsymbol{z} \approx (2.285,\ 0.048),$$
$$\boldsymbol{x}^{(3)} \approx (1.952,\ 0).$$

与 ISTA 的 $17/9 \approx 1.889$ 相比更接近 2，目标差约 0.0024，ISTA 是 0.0123。外推的好处在第三轮就看得到了。

继续迭代，第一分量在第 4 轮越过 2 到达约 2.025，然后缓慢摆回，目标差从第 7 轮的约 1.2×10^{-6} 升到第 8 轮的约 4.4×10^{-6}。这个小问题上 $\kappa = 3$，ISTA 已经很快，FISTA 并不占优，但它显示了 FISTA 的目标值不是逐轮下降的。图 11.15对比了两条路径。

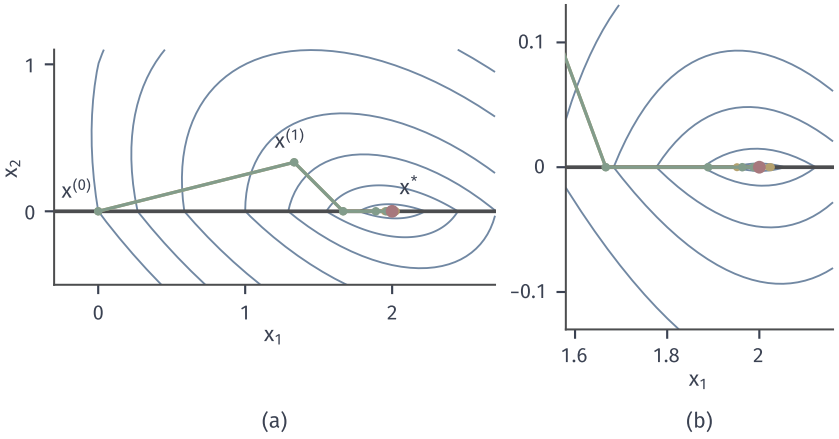


图 11.15　贯穿例 (11.1)上的 ISTA（绿）与 FISTA（黄），蓝线是 F 的等高线，深灰横线是尖点所在的 $x_2 = 0$。(a) 全貌，迭代很快落到 $x_2 = 0$ 上，等高线在这条线上带角。(b)$\boldsymbol{x}^\star = (2, 0)$ 附近放大，FISTA 越过红点后又摆回。

收敛分析　结论的形式与第 6章相同，证明把那里的一步不等式换成引理 11.10。我们把比较点写成任意的 $\boldsymbol{z}$，后面分析光滑化时要用这个写法。

定理 11.12　FISTA 的收敛速率　设 f 凸，梯度 L-Lipschitz 连续，r 是适当、下半连续的凸函数，每步精确计算邻近映射，$\alpha = 1/L$，$\theta^{(t)}$ 按式 (11.41)递推。则对任意 $\boldsymbol{z} \in \operatorname{dom} F$ 和 $T \geq 1$，

$$F(\boldsymbol{x}^{(T)}) - F(\boldsymbol{z}) \leq \frac{2L\|\boldsymbol{x}^{(0)} - \boldsymbol{z}\|_2^2}{(T+1)^2}. \tag{11.42}$$

特别地，若 F 存在最小点 $\boldsymbol{x}^\star$，取 $\boldsymbol{z}=\boldsymbol{x}^\star$ 就得到目标差界。

证明　记 $\theta=\theta^{(t)}$，Δ_t 为目标差 $F(\boldsymbol{x}^{(t)})-F(\boldsymbol{z})$。在引理 11.10中取 $\boldsymbol{y}=\boldsymbol{y}^{(t)}$，$\boldsymbol{x}^+=\boldsymbol{x}^{(t+1)}$，比较点取

$$\boldsymbol{v}=\Big(1-\frac{1}{\theta}\Big)\boldsymbol{x}^{(t)}+\frac{1}{\theta}\boldsymbol{z}.$$

由 F 的凸性，

$$F(\boldsymbol{v})-F(\boldsymbol{z})\le\Big(1-\frac{1}{\theta}\Big)\Delta_t.$$

代入式 (11.38)，并记 $\alpha=1/L$，得

$$\Delta_{t+1}-\Big(1-\frac{1}{\theta}\Big)\Delta_t\le\frac{L}{2}\Big(\|\boldsymbol{y}^{(t)}-\boldsymbol{v}\|_2^2-\|\boldsymbol{x}^{(t+1)}-\boldsymbol{v}\|_2^2\Big).$$

两边乘 θ^2，把 θ 乘进范数。定义

$$\boldsymbol{u}^{(t+1)}=\theta^{(t)}\boldsymbol{x}^{(t+1)}-(\theta^{(t)}-1)\boldsymbol{x}^{(t)}-\boldsymbol{z},$$

则 $\theta\boldsymbol{x}^{(t+1)}-\theta\boldsymbol{v}=\boldsymbol{u}^{(t+1)}$。

再看另一项。令 $\boldsymbol{u}^{(0)}=\boldsymbol{x}^{(0)}-\boldsymbol{z}$。由外推式 (11.40)，$t\ge1$ 时有

$$\theta^{(t)}\boldsymbol{y}^{(t)}=\theta^{(t)}\boldsymbol{x}^{(t)}+(\theta^{(t-1)}-1)(\boldsymbol{x}^{(t)}-\boldsymbol{x}^{(t-1)}),$$

于是

$$\theta\boldsymbol{y}^{(t)}-\theta\boldsymbol{v}=\boldsymbol{u}^{(t)}.$$

$t=0$ 时 $\theta^{(0)}=1$，$\boldsymbol{y}^{(0)}=\boldsymbol{x}^{(0)}$，同一等式也成立。

由递推，$\theta^2-\theta=(\theta^{(t-1)})^2$ $(t\ge1)$，而 $t=0$ 时 $\theta^2-\theta=0$。代入不等式，得到势函数的单调性：

$$(\theta^{(t)})^2\Delta_{t+1}+\frac{L}{2}\|\boldsymbol{u}^{(t+1)}\|_2^2\le(\theta^{(t-1)})^2\Delta_t+\frac{L}{2}\|\boldsymbol{u}^{(t)}\|_2^2.$$

把它从 $t=T-1$ 一直用到 $t=0$，最后一步 $\theta^2-\theta=0$ 使 Δ_0 的项消失，于是

$$(\theta^{(T-1)})^2\Delta_T\le\frac{L}{2}\|\boldsymbol{x}^{(0)}-\boldsymbol{z}\|_2^2.$$

由 $\theta^{(t)}\ge(t+2)/2$ 得 $(\theta^{(T-1)})^2\ge(T+1)^2/4$，代入即得结论。 ■

证明里没有用到 Δ_t 的符号，这也是比较点可以取任意 $\boldsymbol{z}$ 的原因。下面三点是使用时要注意的。第一，界里的 $F(\boldsymbol{x}^{(T)})$ 不要求逐轮下降，例中第 8 轮的回升就是证据；若需要单调，可以在每轮比较后保留较好的点，但这

11.1 次微分
11.2 次梯度方法
11.3 邻近方法
11.4 复合优化
11.4.1 邻近梯度法
11.4.2 加速邻近梯度法（FISTA）
11.4.3 停止条件与计算成本
11.5 光滑化
11.6 代理模型
11.7 本章小结

样改过的算法需要另外分析。第二，$\alpha = 1/L$ 可以换成回溯，但证明要求步长不增。第三，这个证明用到 F 的凸性（比较点 $\boldsymbol{v}$ 的那一步），不能直接用于非凸的 f。

图 11.16用一个条件更差的问题（100×200 的相关设计矩阵）比较两种方法。ISTA 在这种问题上明显受制于条件数，FISTA 在更少的迭代内到达更低的目标差，代价是目标值的振荡。

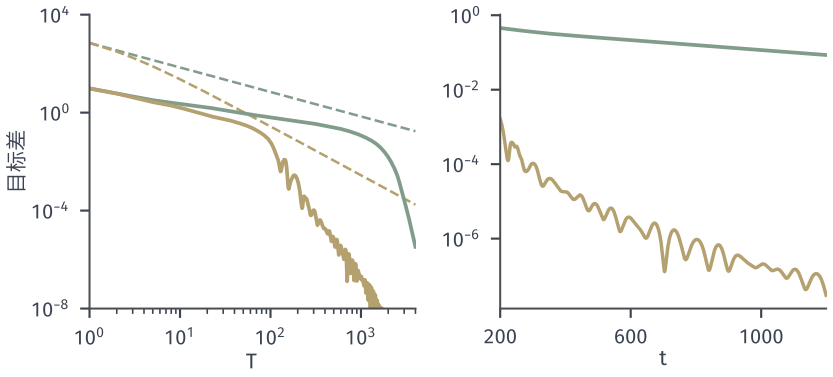


图 11.16　相关设计的 Lasso 上的 ISTA（绿）与 FISTA（黄）。$\boldsymbol{A} \in \mathbb{R}^{100\times200}$ 的列间相关系数 $\rho = 0.9$，λ 取为 $0.005\|\boldsymbol{A}^{\top}\boldsymbol{b}\|_{\infty}$，$\alpha = 1/L$。(a) 目标差（双对数），同色虚线是定理 11.11与定理 11.12的上界。(b) 第 200 到第 1200 轮的放大（半对数），FISTA 的目标差呈周期性振荡，ISTA 单调下降。最优值由高精度运行得到。

11.4.3 停止条件与计算成本

算法要在不知道 $F^{\star}$ 的情况下决定何时停止。无约束光滑问题有 $\|\nabla f\|_2$，复合目标在尖点上没有梯度，需要一个可计算的残差。本小节回答：这个残差是什么，它小意味着什么，以及比较算法时要算哪些账。

邻近梯度映射　把一步更新的位移除以步长，定义**邻近梯度映射**（proximal gradient mapping）

$$\boldsymbol{G}_{\alpha}(\boldsymbol{x}) = \frac{1}{\alpha}\Big(\boldsymbol{x} - \operatorname{prox}_{\alpha r}\big(\boldsymbol{x} - \alpha\nabla f(\boldsymbol{x})\big)\Big). \tag{11.43}$$

$r = 0$ 时它就是 $\nabla f(\boldsymbol{x})$，所以它是梯度在复合目标上的替身。更新可以写成 $\boldsymbol{x}^{+} = \boldsymbol{x} - \alpha\boldsymbol{G}_{\alpha}(\boldsymbol{x})$，这样它和梯度步在形式上完全一样。第 1章提到的非光滑问题的最优性残差，就是这个量。

满足 $\mathbf{0} \in \nabla f(\boldsymbol{x}) + \partial r(\boldsymbol{x})$ 的点称为**复合驻点**（composite stationary point）。这个定义不要求 f 凸。

定理 11.13 映射残差的含义 设 f 梯度 L-Lipschitz 连续，r 是适当、下半连续的凸函数，$\alpha > 0$，$\boldsymbol{x}^+ = \boldsymbol{x} - \alpha \boldsymbol{G}_\alpha(\boldsymbol{x})$。

1. $\boldsymbol{G}_\alpha(\boldsymbol{x}) = \boldsymbol{0}$ 当且仅当 $\boldsymbol{x}$ 是复合驻点。
2. 若 f 凸且 $\boldsymbol{G}_\alpha(\boldsymbol{x}) = \boldsymbol{0}$，则 $\boldsymbol{x}$ 是 F 的全局最小点。
3. 若 $\alpha L \le 1$，则 $\boldsymbol{G}_\alpha(\boldsymbol{x}) + \nabla f(\boldsymbol{x}^+) - \nabla f(\boldsymbol{x}) \in \nabla f(\boldsymbol{x}^+) + \partial r(\boldsymbol{x}^+)$，且范数不超过 $2\|\boldsymbol{G}_\alpha(\boldsymbol{x})\|_2$。$f$ 凸且最小点 $\boldsymbol{x}^\star$ 存在时，

$$F(\boldsymbol{x}^+) - F^\star \le 2\|\boldsymbol{G}_\alpha(\boldsymbol{x})\|_2 \, \|\boldsymbol{x}^+ - \boldsymbol{x}^\star\|_2. \tag{11.44}$$

4. 不要求 f 凸，$\alpha = 1/L$，F 有下界 $F_{\inf}$ 时，邻近梯度法满足

$$\min_{0 \le t < T} \|\boldsymbol{G}_\alpha(\boldsymbol{x}^{(t)})\|_2^2 \le \frac{2L\big(F(\boldsymbol{x}^{(0)}) - F_{\inf}\big)}{T}. \tag{11.45}$$

证明 由式 (11.23)，$\boldsymbol{x}^+$ 由下式刻画：

$$\boldsymbol{G}_\alpha(\boldsymbol{x}) - \nabla f(\boldsymbol{x}) \in \partial r(\boldsymbol{x}^+).$$

第一条：$\boldsymbol{G}_\alpha(\boldsymbol{x}) = \boldsymbol{0}$ 时 $\boldsymbol{x}^+ = \boldsymbol{x}$，上式就是 $-\nabla f(\boldsymbol{x}) \in \partial r(\boldsymbol{x})$。反过来，若 $-\nabla f(\boldsymbol{x}) \in \partial r(\boldsymbol{x})$，则由式 (11.23)，$\boldsymbol{x}$ 本身就是 $\boldsymbol{x} - \alpha \nabla f(\boldsymbol{x})$ 的邻近点，所以 $\boldsymbol{x}^+ = \boldsymbol{x}$。

第二条：f 凸时 $\partial F = \nabla f + \partial r$，用定理 11.4。

第三条：在上式两边加 $\nabla f(\boldsymbol{x}^+)$ 就得到前半部分。范数方面，

$$\|\nabla f(\boldsymbol{x}^+) - \nabla f(\boldsymbol{x})\|_2 \le L\|\boldsymbol{x}^+ - \boldsymbol{x}\|_2 = L\alpha\|\boldsymbol{G}_\alpha(\boldsymbol{x})\|_2 \le \|\boldsymbol{G}_\alpha(\boldsymbol{x})\|_2.$$

f 凸时这个向量是 F 在 $\boldsymbol{x}^+$ 的次梯度，用支撑不等式和 Cauchy 不等式，得到式 (11.44)。

第四条：由刻画式和次梯度不等式，

$$r(\boldsymbol{x}) \ge r(\boldsymbol{x}^+) + \langle \boldsymbol{G}_\alpha(\boldsymbol{x}) - \nabla f(\boldsymbol{x}), \boldsymbol{x} - \boldsymbol{x}^+ \rangle.$$

代入 $\boldsymbol{x} - \boldsymbol{x}^+ = \alpha \boldsymbol{G}_\alpha(\boldsymbol{x})$。再用下降引理

$$f(\boldsymbol{x}^+) \le f(\boldsymbol{x}) + \langle \nabla f(\boldsymbol{x}), \boldsymbol{x}^+ - \boldsymbol{x} \rangle + \frac{L}{2}\|\boldsymbol{x}^+ - \boldsymbol{x}\|_2^2.$$

两式相加，当 $\alpha = 1/L$ 时得到

$$F(\boldsymbol{x}^{+}) \le F(\boldsymbol{x}) - \frac{1}{2L}\|\boldsymbol{G}_{\alpha}(\boldsymbol{x})\|_2^2.$$

对 t 求和，就是式 (11.45)。 ■

第三条给出了可计算的证书：$\boldsymbol{x}^{+}$ 处的一个具体的次梯度，其范数不超过 $2\|\boldsymbol{G}\|$。第四条说明非凸时没有目标差界，只能保证残差变小，这与光滑非凸问题的情况相同。

非凸时残差为零不代表最优。取 $f(x) = -x^2/2$，$r = \iota_{[-1,1]}$，$L = 1$，$\alpha = 1$，则

$$G_1(x) = x - \Pi_{[-1,1]}(2x).$$

$x = 0$ 处 $G_1 = 0$，但 0 是这个问题的最大点，真正的最优解在 ± 1。

用贯穿例核对第三条。ISTA 在 $\boldsymbol{x}^{(3)} = (17/9, 0)$ 处的下一步是 $\boldsymbol{x}^{(4)} = (53/27, 0)$，所以

$$\boldsymbol{G}_{1/3}(\boldsymbol{x}^{(3)}) = 3\Big(\frac{17}{9} - \frac{53}{27},\ 0\Big) = \Big(-\frac{2}{9},\ 0\Big).$$

式 (11.44)的右端是 $2 \cdot \frac{2}{9} \cdot \frac{1}{27} \approx 0.0165$，实际 $F(\boldsymbol{x}^{(4)}) - F^{\star} \approx 0.00137$，上界成立。

停止条件 实际常用的停止条件是残差相对于初始残差足够小：

$$\|\boldsymbol{G}_{\alpha}(\boldsymbol{x}^{(t)})\|_2 \le \varepsilon \max\{1, \|\boldsymbol{G}_{\alpha}(\boldsymbol{x}^{(0)})\|_2\}. \tag{11.46}$$

FISTA 的邻近梯度步是在 $\boldsymbol{y}^{(t)}$ 处算的，$\boldsymbol{G}_{\alpha}(\boldsymbol{y}^{(t)})$ 可以免费得到；若要在 $\boldsymbol{x}^{(t)}$ 处的残差，需要多算一次梯度和邻近映射。图 11.17(a) 显示，FISTA 的残差并不单调，单轮的残差读数可能偶然偏小，稳妥的做法是连续多轮满足条件才停止。

回溯 L 未知或局部 L 远小于全局 L 时，用回溯确定 α。关键是在实际读梯度的点上检验二次上界，对 FISTA 这个点是 $\boldsymbol{y}^{(t)}$，不是 $\boldsymbol{x}^{(t)}$。

回溯的做法是：取当前 α，由式 (11.36)计算 $\boldsymbol{x}^{+}$，检验条件 (11.37)。不满足就令 $\alpha \leftarrow \rho\alpha$（$\rho \in (0,1)$）重算邻近步。引理 11.10只要求这一对点上的上界，所以条件一满足，一步不等式就成立。FISTA 的定理 11.12还需要步长不增，步长增大后势函数不再相消，这时需要专门设计的 θ 递推。

不精确的邻近步 r 的邻近映射没有闭式解时，子问题要迭代求解。设第 t 步邻近子问题的目标值误差不超过 $\epsilon^{(t)}$。已有的结论要求：ISTA 的 $O(1/T)$ 需要 $\sum_t \sqrt{\epsilon^{(t)}} < \infty$，FISTA 的 $O(1/T^2)$ 需要 $\sum_t t\sqrt{\epsilon^{(t)}} < \infty$。

FISTA 的要求更严：外推把误差放大了，误差必须更快地衰减。这个结论的证明需要把误差项带进势函数分析，篇幅较长。它的实际含义是，加速方法的子问题要解得更准，节省的迭代次数要扣掉更贵的子问题。

重启 FISTA 的外推系数 $\beta^{(t)}$ 趋于 1，在强凸的方向上动量过大，表现为目标值的振荡。重启是把 θ 重置为 1、令 $\boldsymbol{y} = \boldsymbol{x}$，相当于扔掉累积的动量。常用的函数值重启规则是：一旦 $F(\boldsymbol{x}^{(t+1)}) > F(\boldsymbol{x}^{(t)})$ 就重启。

图 11.17(b) 显示，同一问题上重启使收敛快了很多。这个规则的保证要单独核对：定理 11.12是从一次连续运行中得到的，重启之后势函数归零，$1/T^2$ 的总界不能直接沿用。每一段的界仍然成立，段长由规则决定；若目标在解附近有二次增长，可以证明周期重启得到线性收敛。如果每步都重启，FISTA 退化成 ISTA。

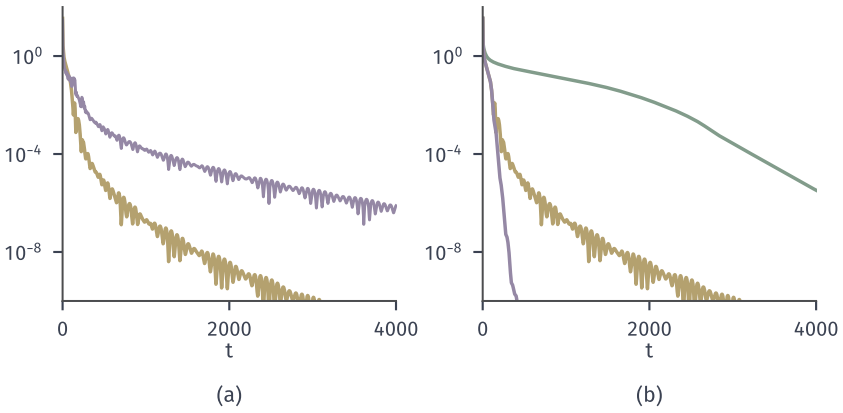


图 11.17 FISTA 的残差与重启，问题与图 11.16相同（半对数坐标）。(a) 黄线是目标差，紫线是 $\boldsymbol{x}^{(t)}$ 处的映射残差范数，两者都不单调。(b) 绿线是 ISTA，黄线是 FISTA，紫线是带函数值重启的 FISTA。

成本对比 比较 ISTA 和 FISTA 时，把一次迭代的成本拆开。

11.1 次微分
11.2 次梯度方法
11.3 邻近方法
11.4 复合优化
11.5 光滑化
11.5.1 Huber 逼近
11.5.2 Moreau 包络
11.5.3 Nesterov 平滑
11.5.4 平滑偏差与求解精度
11.6 代理模型
11.7 本章小结

	ISTA	FISTA
每步梯度	1 次，在 $\boldsymbol{x}^{(t)}$	1 次，在 $\boldsymbol{y}^{(t)}$
每步邻近映射	1 次	1 次
额外存储	无	$\boldsymbol{x}^{(t-1)}$ 与 $\boldsymbol{y}^{(t)}$
回溯	每次试探增加 1 次邻近、1 次 f	同左，试探点是 $\boldsymbol{y}^{(t)}$
目标值单调	是	否
目标差界	$O(1/T)$	$O(1/T^2)$
非凸 f	残差界式 (11.45)	无此保证

表 11.3 ISTA 与 FISTA 的成本和保证。计算函数值用于重启或停止时，FISTA 每轮还要加上一次 F 的计算。

对 Lasso，一次梯度 $\boldsymbol{A}^{\top}(\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b})$ 是两次矩阵向量乘，一次软阈值只要 $O(n)$。主要成本在矩阵向量乘，所以“迭代次数”可以当作比较的单位。当邻近映射本身要迭代时，这个单位就不合适了，比较必须按总的基本运算数，见表 11.3。

11.5 光滑化

邻近方法要求非光滑项的邻近映射便宜。有限个仿射函数的最大值常常做不到这一点：它的邻近子问题本身是一个二次规划。于是要问：能否把尖点磨圆，得到一个光滑的替代目标，再调用第 6章的方法，并算清这样做对原问题到底造成多大误差？

光滑化改变的是目标，第 6章的 Nesterov 加速改变的是迭代规则，这是两件独立的事，后面会把它们配合使用。从本节起，$\mu>0$ 表示平滑参数，μ 越小替代目标越接近原目标。

11.5.1 Huber 逼近

最简单的尖点是 $|x|$ 的原点。把原点两侧长度为 μ 的两段折线换成一段抛物线，外面保持直线，就把尖点磨掉了。外面的直线不能是 $|x|$ 本身，否则接不上，要向下平移一段。设抛物线是 $x^2/(2\mu)$，外侧是 $|x|-c$，在接点 $x=\mu$ 处要求函数值和一阶导数都匹配。

一阶导数：抛物线的导数是 x/μ，在 $x=\mu$ 处等于 1，正好等于外侧直线的斜率，这是抛物线取系数 $1/(2\mu)$ 的原因。

函数值：抛物线在接点的值是 $\mu/2$，要求 $\mu-c=\mu/2$，所以 $c=\mu/2$。

这样得到Huber 函数（Huber function）[4]。

$$h_\mu(x)=\begin{cases}\dfrac{x^2}{2\mu}, & |x|\le\mu,\\[2mm] |x|-\dfrac{\mu}{2}, & |x|>\mu.\end{cases} \tag{11.47}$$

[4] P. J. Huber, *Robust Estimation of a Location Parameter* In The Annals of Mathematical Statistics, 1964, vol. 35, no. 1, pp. 73–101

下面的性质说明它是一个可控的替代。

定理 11.14 Huber 逼近的性质 对任意 $\mu > 0$，h_μ 是连续可微的凸函数，并且

$$0 \le |x| - h_\mu(x) \le \frac{\mu}{2}, \tag{11.48}$$

$$h'_\mu(x) = \min\Big\{\max\Big\{\frac{x}{\mu}, -1\Big\}, 1\Big\}, \qquad |h'_\mu(x) - h'_\mu(y)| \le \frac{1}{\mu}|x - y|. \tag{11.49}$$

证明 由接点匹配，h_μ 在 $\pm\mu$ 处连续可微，其余点是二次函数或线性函数，也可微，导数就是式 (11.49)。这个导数是 x/μ 截断到 $[-1, 1]$，它单调不减（所以 h_μ 凸）。截断不增大距离，而 x/μ 的 Lipschitz 常数是 $1/\mu$，所以导数 $1/\mu$-Lipschitz。

偏差只需看 $x \ge 0$。外侧 $|x| - h_\mu(x) = \mu/2$。内侧令 $e(x) = x - x^2/(2\mu)$，$e(0) = 0$，$e'(x) = 1 - x/\mu \ge 0$，所以 e 从 0 单调增到 $e(\mu) = \mu/2$。 ■

图 11.18画出两个 μ。(a) 中 h_μ 从下方逼近 $|x|$，μ 减半时差也减半。(b) 中 $|x|$ 的导数在原点跳变，h'_μ 用一段斜率 $1/\mu$ 的直线走完这段跳变。μ 减半，过渡段的斜率加倍，这就是梯度 Lipschitz 常数 $1/\mu$ 的来源。

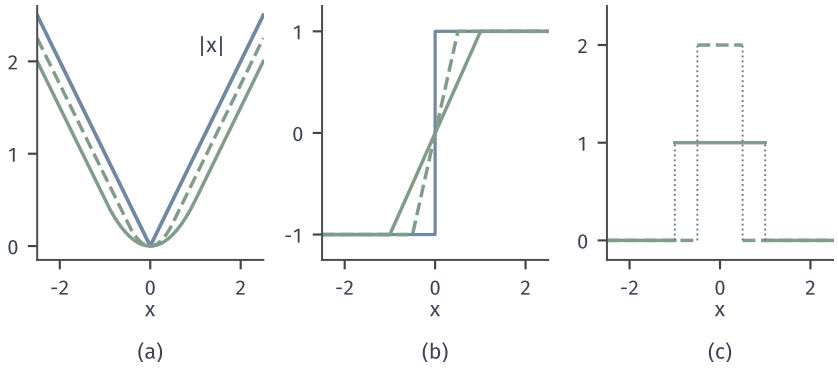


图 11.18 Huber 函数。蓝线是 $|x|$ 及其导数，绿色实线和虚线分别是 $\mu = 1$ 和 $\mu = \frac{1}{2}$ 的 h_μ。(a) 函数值，h_μ 在外侧与 $|x|$ 平行。(b) 一阶导数，连续但有拐点。(c) 二阶导数，在接点 $\pm\mu$ 处跳变，所以 h_μ 在这些点不是二阶可微的。

要留意图 11.18(c)。h_μ 的二阶导数在 $|x| < \mu$ 处是 $1/\mu$，在外面是 0，在接点上不存在。所以 h_μ 的梯度 Lipschitz，但不是处处二阶可微。第 5章的一阶方法只需要前者，可以直接用；第 7章的牛顿法在接点附近没有定义好的 Hessian，要专门处理。

11.1 次微分
11.2 次梯度方法
11.3 邻近方法
11.4 复合优化
11.5 光滑化
11.5.1 Huber 逼近
11.5.2 Moreau 包络
11.5.3 Nesterov 平滑
11.5.4 平滑偏差与求解精度
11.6 代理模型
11.7 本章小结

11.5.2 Moreau 包络

Huber 函数的抛物线从何而来？它其实是第 11.3节的邻近子问题的副产品：邻近映射取的是最小点，如果取最优值，就得到一个新函数。

定义 11.15　Moreau 包络　设 f 是适当、下半连续的凸函数，$\mu > 0$。称

$$M_{\mu f}(\boldsymbol{x}) = \min_{\boldsymbol{y}} \left\{ f(\boldsymbol{y}) + \frac{1}{2\mu}\|\boldsymbol{y}-\boldsymbol{x}\|_2^2 \right\} \tag{11.50}$$

为 f 的Moreau 包络（Moreau envelope）。

由定理 11.8，最小值在唯一的 $\boldsymbol{p} = \operatorname{prox}_{\mu f}(\boldsymbol{x})$ 处取到，所以 $M_{\mu f}$ 处处有限。

对 $f = |\cdot|$ 用软阈值计算。若 $|x| \le \mu$，$p = 0$，结果是 $x^2/(2\mu)$。若 $|x| > \mu$，$p = x - \mu\operatorname{sign}(x)$，$|p| = |x| - \mu$，距离项是 $\mu/2$，结果是 $|x| - \mu/2$。两种情形合起来正是式 (11.47)：

$$M_{\mu|\cdot|} = h_\mu. \tag{11.51}$$

这个包络的图景是：把一个以 $\boldsymbol{x}$ 为顶点的小抛物线碗从下往上抬，碰到 f 时碗顶的高度就是 $M_{\mu f}(\boldsymbol{x})$。图 11.19(a) 画出了三段折线的包络，折点都被抛物线磨圆。

定理 11.16　Moreau 包络的光滑性与最小点　设 f 是适当、下半连续的凸函数，$\mu > 0$。则 $M_{\mu f}$ 是凸函数，处处可微，且

$$\nabla M_{\mu f}(\boldsymbol{x}) = \frac{\boldsymbol{x} - \operatorname{prox}_{\mu f}(\boldsymbol{x})}{\mu}. \tag{11.52}$$

梯度是 $1/\mu$-Lipschitz 的。此外 $M_{\mu f} \le f$，并且 $M_{\mu f}$ 与 f 有相同的最小值和相同的最小点集合。

证明　记 $\boldsymbol{p} = \operatorname{prox}_{\mu f}(\boldsymbol{x})$，$\boldsymbol{s} = (\boldsymbol{x}-\boldsymbol{p})/\mu$，由式 (11.23)有 $\boldsymbol{s} \in \partial f(\boldsymbol{p})$。任取 $\boldsymbol{y}$，记 $\boldsymbol{q} = \operatorname{prox}_{\mu f}(\boldsymbol{y})$。

上界。把 $\boldsymbol{p}$ 作为 $\boldsymbol{y}$ 处子问题的试探点，

$$M_{\mu f}(\boldsymbol{y}) \le f(\boldsymbol{p}) + \frac{1}{2\mu}\|\boldsymbol{p}-\boldsymbol{y}\|_2^2 = M_{\mu f}(\boldsymbol{x}) + \langle \boldsymbol{s}, \boldsymbol{y}-\boldsymbol{x}\rangle + \frac{1}{2\mu}\|\boldsymbol{y}-\boldsymbol{x}\|_2^2.$$

第二个等号是把 $\boldsymbol{p}-\boldsymbol{y} = (\boldsymbol{p}-\boldsymbol{x}) + (\boldsymbol{x}-\boldsymbol{y})$ 展开，并用 $\boldsymbol{p}-\boldsymbol{x} = -\mu\boldsymbol{s}$。

下界。由 $\boldsymbol{s} \in \partial f(\boldsymbol{p})$，

$$f(\boldsymbol{q}) \geq f(\boldsymbol{p}) + \langle \boldsymbol{s}, \boldsymbol{q} - \boldsymbol{p} \rangle,$$

于是

$$M_{\mu f}(\boldsymbol{y}) - M_{\mu f}(\boldsymbol{x}) \geq \langle \boldsymbol{s}, \boldsymbol{q} - \boldsymbol{p} \rangle + \frac{1}{2\mu}\Big(\|\boldsymbol{q} - \boldsymbol{y}\|_2^2 - \|\boldsymbol{p} - \boldsymbol{x}\|_2^2 \Big).$$

记 $\boldsymbol{a} = \boldsymbol{q} - \boldsymbol{y}$，$\boldsymbol{b} = \boldsymbol{p} - \boldsymbol{x} = -\mu \boldsymbol{s}$，再用恒等式

$$\|\boldsymbol{a}\|_2^2 - \|\boldsymbol{b}\|_2^2 = \|\boldsymbol{a} - \boldsymbol{b}\|_2^2 + 2\langle \boldsymbol{a} - \boldsymbol{b}, \boldsymbol{b} \rangle,$$

右端化为

$$\langle \boldsymbol{s}, \boldsymbol{y} - \boldsymbol{x} \rangle + \frac{1}{2\mu}\|\boldsymbol{a} - \boldsymbol{b}\|_2^2 \geq \langle \boldsymbol{s}, \boldsymbol{y} - \boldsymbol{x} \rangle.$$

上下界合起来，

$$0 \leq M_{\mu f}(\boldsymbol{y}) - M_{\mu f}(\boldsymbol{x}) - \langle \boldsymbol{s}, \boldsymbol{y} - \boldsymbol{x} \rangle \leq \frac{1}{2\mu}\|\boldsymbol{y} - \boldsymbol{x}\|_2^2.$$

所以 $M_{\mu f}$ 在 $\boldsymbol{x}$ 处可微，梯度为 $\boldsymbol{s}$。下界对所有 $\boldsymbol{x}$ 成立，说明处处存在次梯度，因而是凸函数。

Lipschitz 性。记 $\boldsymbol{u} = \boldsymbol{x} - \boldsymbol{y}$，$\boldsymbol{w} = \boldsymbol{p} - \boldsymbol{q}$，由式 (11.24)得 $\|\boldsymbol{w}\|_2^2$ 不超过 $\langle \boldsymbol{u}, \boldsymbol{w} \rangle$，所以

$$\|\boldsymbol{u} - \boldsymbol{w}\|_2^2 = \|\boldsymbol{u}\|_2^2 - 2\langle \boldsymbol{u}, \boldsymbol{w} \rangle + \|\boldsymbol{w}\|_2^2 \leq \|\boldsymbol{u}\|_2^2 - \|\boldsymbol{w}\|_2^2 \leq \|\boldsymbol{u}\|_2^2.$$

梯度之差是 $(\boldsymbol{u} - \boldsymbol{w})/\mu$，范数不超过 $\|\boldsymbol{u}\|_2/\mu$。

最小点。在式 (11.50)中取 $\boldsymbol{y} = \boldsymbol{x}$ 得 $M_{\mu f} \leq f$。$\boldsymbol{x}$ 是 $M_{\mu f}$ 的最小点，当且仅当梯度为零，当且仅当 $\boldsymbol{x} = \operatorname{prox}_{\mu f}(\boldsymbol{x})$，由式 (11.23)当且仅当 $\boldsymbol{0} \in \partial f(\boldsymbol{x})$。此时距离项为零，$M_{\mu f}(\boldsymbol{x}) = f(\boldsymbol{x})$，所以最小值相同。 ■

对 $|x|$ 验证式 (11.52)。$x = 2$，$\mu = 1$ 时 $p = 1$，公式给出 $(2 - 1)/1 = 1$，这就是 Huber 函数在外侧的斜率。$x = 0.6$ 时 $p = 0$，公式给出 0.6，与 $h_1'(0.6) = 0.6$ 一致。

平滑一项不等于保持解　定理说整个凸目标的包络与原函数有相同的最小点。但实用上想平滑的通常只是复合目标的一项。这时最小点一般会变。

11.1 次微分
11.2 次梯度方法
11.3 邻近方法
11.4 复合优化
11.5 光滑化
11.5.1 Huber 逼近
11.5.2 Moreau 包络
11.5.3 Nesterov 平滑
11.5.4 平滑偏差与求解精度
11.6 代理模型
11.7 本章小结

取 $F(x)=\frac{1}{2}(x-\frac{1}{2})^2+|x|$。在 $x=0$ 处 F 的次微分是 $-\frac{1}{2}+[-1,1]$，包含零，所以 $x^\star=0$。只把 $|x|$ 换成包络 h_1，得到光滑目标 $F_1(x)=\frac{1}{2}(x-\frac{1}{2})^2+h_1(x)$，在 $|x|\le 1$ 上令导数为零：

$$x-\frac{1}{2}+x=0,\qquad x=\frac{1}{4}.$$

原问题的解是 0，这个替代的解是 $\frac{1}{4}$。图 11.19(b) 显示了这一点。代入原目标，$F(\frac{1}{4})=\frac{9}{32}\approx 0.281$，比 $F^\star=\frac{1}{8}$ 高，$\frac{1}{4}$ 不再有“稀疏”的零分量。

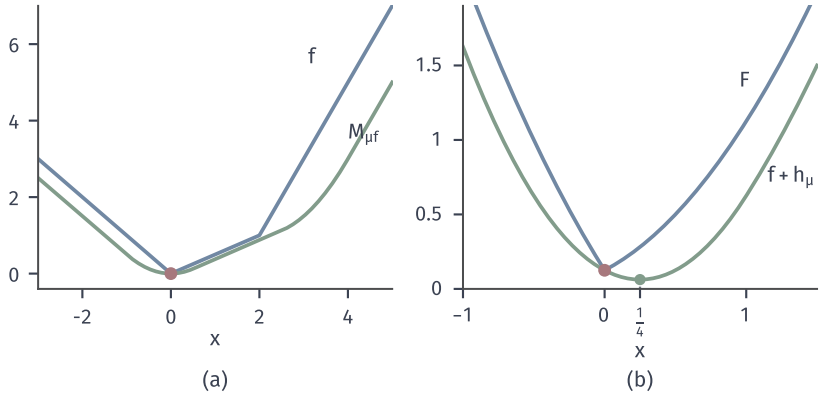


图 11.19 Moreau 包络（$\mu=1$）。(a) 三段折线 f（蓝）与它的包络（绿），最小点相同（红点）。(b)$F(x)=\frac{1}{2}(x-\frac{1}{2})^2+|x|$（蓝）的最小点是 0（红点），只平滑绝对值项后，绿色替代目标的最小点移到 $\frac{1}{4}$（绿点）。

求包络的梯度 (11.52)要算一次邻近映射。所以包络不能绕开邻近映射：当 prox 不便宜时，这条路同样走不通。这正是下面的方法要解决的问题。

11.5.3 Nesterov 平滑

许多非光滑函数天然写成最大值，比如分段线性函数和 ℓ_1 范数。最大值函数的梯度在活跃分支切换时跳变。Nesterov 平滑的想法是让这种切换变得连续，方法是在最大化问题的变量上加入一点强凸惩罚，使每个 $\boldsymbol{x}$ 对应唯一的内层最优点，而这个最优点随 $\boldsymbol{x}$ 连续变化。

11.5.3.1 最大值表示的正则化

设目标有最大值结构：$\boldsymbol{A}\in\mathbb{R}^{p\times n}$，$\boldsymbol{Q}\subset\mathbb{R}^p$ 是非空紧凸集，ϕ 是 $\boldsymbol{Q}$ 上的连续凸函数，

$$f(\boldsymbol{x})=\max_{\boldsymbol{u}\in\boldsymbol{Q}}\{\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{u}\rangle-\phi(\boldsymbol{u})\}. \tag{11.53}$$

例如 $|x|=\max_{|u|\le 1}xu$，最优的 u 是 $\operatorname{sign}(x)$，在 $x=0$ 处从 -1 跳到 1，这就是梯度的跳变。

在 $\boldsymbol{u}$ 的空间选一个范数 $\|\cdot\|_{Q}$。设 $d:\boldsymbol{Q}\to\mathbb{R}$ 连续，σ-强凸（对这个范数），且 $\min_{Q} d=0$。记 $D=\max_{Q} d$，矩阵的范数

$$\|\boldsymbol{A}\|=\max\{\langle \boldsymbol{A}\boldsymbol{x},\boldsymbol{u}\rangle:\ \|\boldsymbol{x}\|_2\le 1,\ \|\boldsymbol{u}\|_{Q}\le 1\}.$$

这里的 σ-强凸是指对 $\boldsymbol{u},\boldsymbol{v}\in\boldsymbol{Q}$，$\theta\in[0,1]$，

$$d\big(\theta\boldsymbol{u}+(1-\theta)\boldsymbol{v}\big)\le\theta d(\boldsymbol{u})+(1-\theta)d(\boldsymbol{v})-\frac{\sigma}{2}\theta(1-\theta)\|\boldsymbol{u}-\boldsymbol{v}\|_{Q}^{2}. \tag{11.54}$$

在最大化式里减去 μd，定义Nesterov 平滑（Nesterov smoothing）

$$f_{\mu}(\boldsymbol{x})=\max_{\boldsymbol{u}\in\boldsymbol{Q}}\{\langle \boldsymbol{A}\boldsymbol{x},\boldsymbol{u}\rangle-\phi(\boldsymbol{u})-\mu d(\boldsymbol{u})\}. \tag{11.55}$$

定理 11.17　Nesterov 平滑的性质　在上述条件下，式 (11.55)对每个 $\boldsymbol{x}$ 有唯一的最大点，记作 $\boldsymbol{u}_{\mu}(\boldsymbol{x})$。函数 f_{μ} 凸且可微，并且

$$\nabla f_{\mu}(\boldsymbol{x})=\boldsymbol{A}^{\top}\boldsymbol{u}_{\mu}(\boldsymbol{x}), \tag{11.56}$$

$$f_{\mu}(\boldsymbol{x})\le f(\boldsymbol{x})\le f_{\mu}(\boldsymbol{x})+\mu D, \tag{11.57}$$

$$\|\nabla f_{\mu}(\boldsymbol{x})-\nabla f_{\mu}(\boldsymbol{y})\|_2\le\frac{\|\boldsymbol{A}\|^{2}}{\mu\sigma}\|\boldsymbol{x}-\boldsymbol{y}\|_2. \tag{11.58}$$

证明　记式 (11.55)中大括号内的函数为 $\Psi_{\boldsymbol{x}}(\boldsymbol{u})$。$\phi$ 是凸的，μd 是 $\mu\sigma$-强凸的，所以 $\Psi_{\boldsymbol{x}}$ 是 $\mu\sigma$-强凹的连续函数，在紧凸集上有唯一的最大点。

强凹性给出最大点处的二次间隙。设 $\boldsymbol{u}_1$ 是最大点，对任意 $\boldsymbol{u}\in\boldsymbol{Q}$ 和 $\theta\in(0,1)$，令 $\boldsymbol{w}=\theta\boldsymbol{u}+(1-\theta)\boldsymbol{u}_1\in\boldsymbol{Q}$，

$$\Psi_{\boldsymbol{x}}(\boldsymbol{u}_1)\ge\Psi_{\boldsymbol{x}}(\boldsymbol{w})\ge\theta\Psi_{\boldsymbol{x}}(\boldsymbol{u})+(1-\theta)\Psi_{\boldsymbol{x}}(\boldsymbol{u}_1)+\frac{\mu\sigma}{2}\theta(1-\theta)\|\boldsymbol{u}-\boldsymbol{u}_1\|_{Q}^{2}.$$

整理后除以 θ，再令 $\theta\to 0$，得到

$$\Psi_{\boldsymbol{x}}(\boldsymbol{u})\le\Psi_{\boldsymbol{x}}(\boldsymbol{u}_1)-\frac{\mu\sigma}{2}\|\boldsymbol{u}-\boldsymbol{u}_1\|_{Q}^{2}. \tag{11.59}$$

Lipschitz 估计。对 $\boldsymbol{x}_1,\boldsymbol{x}_2$，记 $\boldsymbol{u}_i=\boldsymbol{u}_{\mu}(\boldsymbol{x}_i)$。式 (11.59)两次使用后相加，$\phi$ 和 d 的项消去，得到

$$\mu\sigma\|\boldsymbol{u}_1-\boldsymbol{u}_2\|_{Q}^{2}\le\langle \boldsymbol{A}(\boldsymbol{x}_1-\boldsymbol{x}_2),\boldsymbol{u}_1-\boldsymbol{u}_2\rangle\le\|\boldsymbol{A}\|\,\|\boldsymbol{x}_1-\boldsymbol{x}_2\|_2\,\|\boldsymbol{u}_1-\boldsymbol{u}_2\|_{Q}.$$

约去一个 $\|\boldsymbol{u}_1-\boldsymbol{u}_2\|_Q$，得到

$$\|\boldsymbol{u}_1-\boldsymbol{u}_2\|_Q \le \frac{\|\boldsymbol{A}\|}{\mu\sigma}\|\boldsymbol{x}_1-\boldsymbol{x}_2\|_2.$$

梯度公式。f_μ 是一族仿射函数的上确界，所以是凸的。取 $\boldsymbol{u}=\boldsymbol{u}_\mu(\boldsymbol{x})$，$\boldsymbol{u}'=\boldsymbol{u}_\mu(\boldsymbol{y})$，一方面

$$f_\mu(\boldsymbol{y}) \ge \Psi_{\boldsymbol{y}}(\boldsymbol{u}) = f_\mu(\boldsymbol{x}) + \langle \boldsymbol{A}^{\top}\boldsymbol{u}, \boldsymbol{y}-\boldsymbol{x}\rangle.$$

另一方面，由 $\Psi_{\boldsymbol{x}}(\boldsymbol{u}') \le f_\mu(\boldsymbol{x})$，

$$f_\mu(\boldsymbol{y}) = \Psi_{\boldsymbol{y}}(\boldsymbol{u}') \le f_\mu(\boldsymbol{x}) + \langle \boldsymbol{A}^{\top}\boldsymbol{u}, \boldsymbol{y}-\boldsymbol{x}\rangle + \langle \boldsymbol{A}(\boldsymbol{y}-\boldsymbol{x}), \boldsymbol{u}'-\boldsymbol{u}\rangle.$$

由上一段的估计，最后一项不超过 $\|\boldsymbol{A}\|^2\|\boldsymbol{y}-\boldsymbol{x}\|_2^2/(\mu\sigma)$，是二阶小量，所以 f_μ 可微，梯度是 $\boldsymbol{A}^{\top}\boldsymbol{u}$。

式 (11.58)由上面的估计和下面的范数关系得到：

$$\|\boldsymbol{A}^{\top}(\boldsymbol{u}_1-\boldsymbol{u}_2)\|_2 \le \|\boldsymbol{A}\|\,\|\boldsymbol{u}_1-\boldsymbol{u}_2\|_Q.$$

偏差。由 $0 \le d \le D$，对每个 $\boldsymbol{u}$ 有

$$\langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{u}\rangle - \phi(\boldsymbol{u}) - \mu D \le \Psi_{\boldsymbol{x}}(\boldsymbol{u}) \le \langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{u}\rangle - \phi(\boldsymbol{u}).$$

对 $\boldsymbol{u}$ 取最大，就是式 (11.57)。 ■

每个条件的作用都清楚：紧性使 D 有限，从而偏差有限；强凸使内层解唯一且随 $\boldsymbol{x}$ 连续变化，梯度跳变由此被抹平；$\min d = 0$ 让偏差是单侧的。μ 变小时偏差 μD 变小，Lipschitz 常数 $\|\boldsymbol{A}\|^2/(\mu\sigma)$ 变大，后面就是要权衡这两者。

用菱形目标算一遍。写成 $\boldsymbol{A}=\operatorname{diag}(1,2)$，$\boldsymbol{Q}=[-1,1]^2$，$\phi=0$，$d(\boldsymbol{u})=\frac{1}{2}\|\boldsymbol{u}\|_2^2$，$\sigma=1$，范数取欧氏范数。此时 $D=1$，$\|\boldsymbol{A}\|=2$。内层问题按坐标分开，解是把 $(\boldsymbol{A}\boldsymbol{x})_i/\mu$ 截断到 $[-1,1]$，把解代回，得到

$$f_\mu(\boldsymbol{x}) = h_\mu(x_1) + h_\mu(2x_2), \qquad \nabla f_\mu(\boldsymbol{x}) = \boldsymbol{A}^{\top}\boldsymbol{u}_\mu(\boldsymbol{x}).$$

结果是两个 Huber 函数之和，第二项的二阶导数最大为 $4/\mu$，正好是 $\|\boldsymbol{A}\|^2/(\mu\sigma)$。在 $\boldsymbol{x}=(1,0)$，$\mu=1$ 处，

$$\boldsymbol{u}_1=(1,0), \qquad f_1(\boldsymbol{x})=\frac{1}{2}, \qquad f(\boldsymbol{x})-f_1(\boldsymbol{x})=\frac{1}{2} \le \mu D = 1.$$

内层求解的成本决定这个方法是否划算。本例内层是逐坐标截断，$O(n)$；$\boldsymbol{Q}$ 是单纯形且 d 取下面的负熵时也是闭式解。若 $\boldsymbol{Q}$ 或 ϕ 没有这样的结构，每次读梯度都要解一个内层优化，只能得到近似的 $\boldsymbol{u}_\mu$，这时梯度带有误差，上面的保证需要重新计入这个误差。

11.5.3.2 对数和指数平滑

最常用的实例是有限个仿射函数的最大值，也就是开头提到的邻近映射不便宜的情形。设 $\ell_i(\boldsymbol{x}) = \langle \boldsymbol{a}_i, \boldsymbol{x}\rangle + b_i$，$i = 1, \dots, m$，这里 m 是分支个数。

把“选一个最大的分支”写成单纯形 $\Delta_m = \{\boldsymbol{u} \geq \boldsymbol{0} : \sum_i u_i = 1\}$ 上的线性最大化，权重集中在最大的分支上时取到最大值：

$$f(\boldsymbol{x}) = \max_i \ell_i(\boldsymbol{x}) = \max_{\boldsymbol{u}\in\Delta_m} \sum_{i=1}^{m} u_i \ell_i(\boldsymbol{x}).$$

这符合式 (11.53)，$\boldsymbol{A}$ 的第 i 行是 $\boldsymbol{a}_i^{\top}$，$\phi(\boldsymbol{u}) = -\sum_i u_i b_i$。选择归一化的负熵（negative entropy）作为 d：

$$d(\boldsymbol{u}) = \sum_{i=1}^{m} u_i \ln u_i + \ln m.$$

d 的最小值 0 在均匀分布处取到，最大值 $\ln m$ 在顶点处取到，所以 $D = \ln m$。

内层问题是

$$\max_{\boldsymbol{u}\in\Delta_m} \sum_i u_i \ell_i - \mu \sum_i u_i \ln u_i - \mu \ln m.$$

对约束 $\sum_i u_i = 1$ 引入乘子，令对 u_i 的偏导数为零，得 $\ell_i - \mu(\ln u_i + 1) + \nu = 0$，也就是 $u_i \propto \exp(\ell_i/\mu)$。解是 softmax 权重：

$$p_i(\boldsymbol{x}) = \frac{\exp(\ell_i(\boldsymbol{x})/\mu)}{\sum_{k=1}^{m} \exp(\ell_k(\boldsymbol{x})/\mu)}. \tag{11.60}$$

记分母为 Z，由 $\ln p_i = \ell_i/\mu - \ln Z$，代回内层目标，$\ell_i$ 的项消去，得到

$$f_\mu(\boldsymbol{x}) = \mu \ln \frac{1}{m} \sum_{i=1}^{m} \exp\Big(\frac{\ell_i(\boldsymbol{x})}{\mu}\Big). \tag{11.61}$$

不做归一化的版本是最常见的**对数和指数函数**（log-sum-exp function）

$$\varphi_\mu(\boldsymbol{x}) = \mu \ln \sum_{i=1}^{m} \exp\Big(\frac{\ell_i(\boldsymbol{x})}{\mu}\Big) = f_\mu(\boldsymbol{x}) + \mu \ln m. \tag{11.62}$$

两者只差常数 $\mu \ln m$，梯度相同。由式 (11.57)，前者从下方逼近，后者从上方逼近：

$$f - \mu \ln m \le f_\mu \le f \le \varphi_\mu \le f + \mu \ln m. \tag{11.63}$$

上方这一半可以直接看出来。把 $\exp(f/\mu)$ 提到求和号外，求和的每一项不超过 1，最大的一项等于 1，所以和在 1 到 m 之间。

对 $\boldsymbol{x}$ 求导，梯度是 softmax 加权的分支斜率：

$$\nabla f_\mu(\boldsymbol{x}) = \sum_{i=1}^{m} p_i(\boldsymbol{x})\, \boldsymbol{a}_i. \tag{11.64}$$

再求一次导，Hessian 是斜率的协方差除以 μ：

$$\nabla^2 f_\mu = \frac{1}{\mu}\Big(\sum_i p_i \boldsymbol{a}_i \boldsymbol{a}_i^{\top} - \bar{\boldsymbol{a}}\bar{\boldsymbol{a}}^{\top}\Big), \qquad \bar{\boldsymbol{a}} = \sum_i p_i \boldsymbol{a}_i.$$

对单位向量 $\boldsymbol{v}$，$\boldsymbol{v}^{\top}\nabla^2 f_\mu \boldsymbol{v}$ 是取值 $\langle \boldsymbol{a}_i, \boldsymbol{v}\rangle$ 的随机变量的方差除以 μ，不超过 $\max_i \|\boldsymbol{a}_i\|_2^2/\mu$。所以

$$L_\mu = \frac{\max_i \|\boldsymbol{a}_i\|_2^2}{\mu}. \tag{11.65}$$

这也符合定理 11.17：负熵在 Δ_m 上对 ℓ_1 范数是 1-强凸的（Pinsker 不等式），相应的 $\|\boldsymbol{A}\| = \max_i \|\boldsymbol{a}_i\|_2$，式 (11.65)正是 $\|\boldsymbol{A}\|^2/(\mu\sigma)$。这里取 ℓ_1 范数，比欧氏范数给出的 $\|\boldsymbol{A}\|_2^2/\mu$ 更小，这就是在定理中允许一般范数的原因。

用三段折线核对。$\mu = 1$ 时，$x = 0$ 处三支的值是 $0, 0, -3$，权重正比于 $1, 1, e^{-3}$，也就是

$$\boldsymbol{p} \approx (0.488,\ 0.488,\ 0.024).$$

导数是权重与斜率的内积：

$$f_1'(0) \approx 0.488 \cdot (-1) + 0.488 \cdot \tfrac{1}{2} + 0.024 \cdot 2 \approx -0.195.$$

原函数在 $x = 0$ 的次微分是 $[-1, \tfrac{1}{2}]$，这个数落在其中。图 11.20(a) 画出了 $\mu = 0.2$ 时权重随 x 的变化：原本的分支切换被抹成了平滑的过渡。图 11.20(b) 中，导数的跳变被抹平，μ 越小越接近原来的台阶。

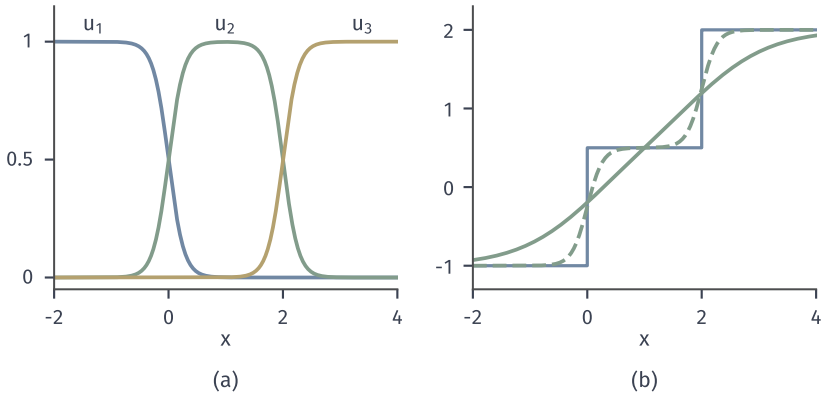


图 11.20 三段折线的熵平滑。(a)$\mu = 0.2$ 时的内层最优权重 $u_i = p_i(x)$，蓝、绿、黄分别对应斜率 $-1, \frac{1}{2}, 2$ 的分支。(b) 蓝线是原函数的次微分（台阶），绿色虚线和实线分别是 $\mu = 0.2$ 和 $\mu = 1$ 的 f'_μ，由权重加权平均得到。

与 Huber 比较 $|x| = \max\{x, -x\}$ 有两个分支，$m = 2$，把两种平滑写出来：

$$\varphi_\mu(x) = \mu \ln\bigl(e^{x/\mu} + e^{-x/\mu}\bigr), \qquad f_\mu(x) = \mu \ln \cosh \frac{x}{\mu}.$$

两者的导数都是 $\tanh(x/\mu)$，二阶导数都不超过 $1/\mu$，这与 Huber 函数的 $1/\mu$ 相同。差别在形状和偏差，图 11.21对比了三者（$\mu = \frac{1}{2}$）。

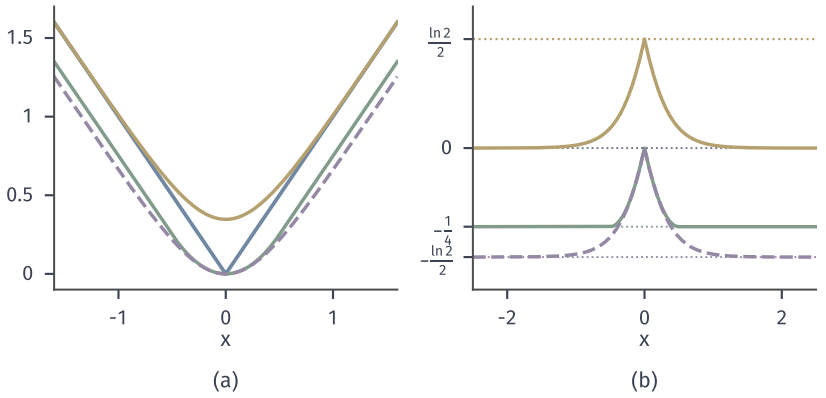


图 11.21 $|x|$（蓝）的三种平滑，$\mu = \frac{1}{2}$：Huber（绿）、未平移的对数和指数函数 φ_μ（黄）、归一化版本 f_μ（紫色虚线）。(a) 函数值。(b) 替代函数减 $|x|$ 的差，点线标出各自的极限或最大偏差 $-\mu/2$、$\pm\mu \ln 2$。

Huber 函数在 $\pm\mu$ 外与 $|x|$ 只差一个常数，偏差 $\mu/2$；对数和指数函数的过渡是指数式的，走不到精确的斜率 ± 1，偏差最大是 $\mu \ln 2 \approx 0.693\mu$。上方的 φ_μ 偏差在原点最大，向外趋于零；下方的 f_μ 在原点无偏差，向外趋于 $\mu \ln 2$。表 11.4汇总了这些差别。

11.1 次微分
11.2 次梯度方法
11.3 邻近方法
11.4 复合优化
11.5 光滑化
11.5.1 Huber 逼近
11.5.2 Moreau 包络
11.5.3 Nesterov 平滑
11.5.4 平滑偏差与求解精度
11.6 代理模型
11.7 本章小结

	Huber	上方 φ_μ	下方 f_μ
构造	Moreau 包络	负熵，不平移	负熵，归一化
偏差范围	$[0, \mu/2]$	$[0, \mu \ln 2]$	$[0, \mu \ln 2]$
相对原函数	下方	上方	下方
梯度 Lipschitz	$1/\mu$	$1/\mu$	$1/\mu$
二阶可微	否	是	是
推广到 m 个分支	需要邻近映射	显式，偏差 $\mu \ln m$	显式，偏差 $\mu \ln m$

表 11.4 $|x|$ 的三种光滑替代。

11.5.4 平滑偏差与求解精度

光滑化引入了两种误差：替代目标与原目标的差别，以及替代问题没有求准的部分。给定原问题的精度要求，这两者要联合分配。

误差分解 设 F 是原目标，光滑替代 F_μ 满足统一偏差界 $F_\mu \le F \le F_\mu + \mu D$，例如式 (11.57)。对任意 $\hat{\boldsymbol{x}}$ 和 F 的最小点 $\boldsymbol{x}^\star$，由 $F(\hat{\boldsymbol{x}}) \le F_\mu(\hat{\boldsymbol{x}}) + \mu D$ 和 $F_\mu(\boldsymbol{x}^\star) \le F^\star$，

$$F(\hat{\boldsymbol{x}}) - F^\star \le \big(F_\mu(\hat{\boldsymbol{x}}) - F_\mu(\boldsymbol{x}^\star)\big) + \mu D. \tag{11.66}$$

右端第一项是求解误差，可以靠多走几步减小；第二项是平滑偏差，无论替代问题解得多准都留在那里。这里的比较点取 $\boldsymbol{x}^\star$ 而不是 F_μ 的最小点，因此第一项可以直接用定理 11.12的任意比较点版本控制。上方逼近的 φ_μ 与 f_μ 只差常数，上式同样适用。

图 11.22(a) 在 $\mathbb{R}^2$ 上 7 个分支的问题上显示了这件事：固定 μ 跑加速方法，原目标差最终停在由 $\mu \ln m$ 决定的平台上；μ 越小，平台越低，到达平台需要的步数越多。

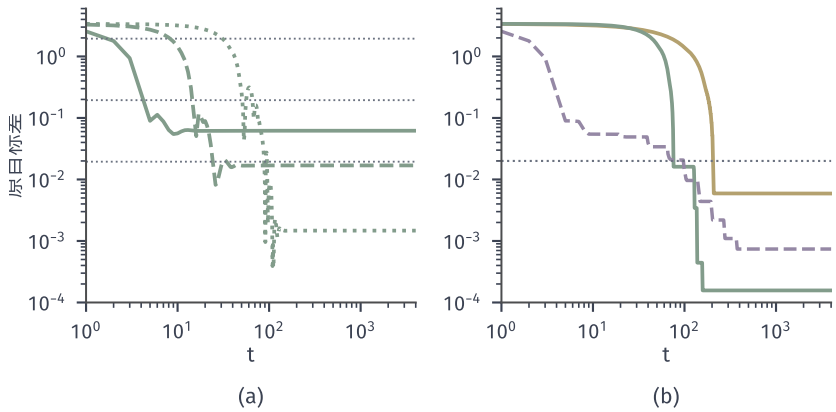


图 11.22 偏差与求解精度（双对数坐标）。目标是平面上 7 个等分方向的单位斜率分支的最大值，$\boldsymbol{x}^{(0)}=(3,2)$，用熵平滑配合 Nesterov 加速，$\alpha=1/L_\mu=\mu$。(a) 绿色实线、虚线、点线分别是 $\mu=1,0.1,0.01$ 时原目标差，灰色点线是偏差上界 $\mu\ln 7$。(b) 目标精度 $\varepsilon=0.02$（灰色点线）：黄线是固定步长 $\alpha=\varepsilon$ 的次梯度法的最好值，绿线是取 $\mu=\varepsilon/(2\ln 7)$ 的平滑加速法，紫色虚线是 μ 逐阶段减半、同步更新步长的方案。

总成本 下面的定理把偏差、光滑常数、加速方法合在一起。

定理 11.18 平滑加速法的总成本 设 $F=\psi+f$，ψ 是凸函数且梯度 L_ψ-Lipschitz 连续（可以为零），f 具有式 (11.53)的结构，F 存在最小点 $\boldsymbol{x}^\star$，$\|\boldsymbol{x}^{(0)}-\boldsymbol{x}^\star\|_2\le R$。对 $F_\mu=\psi+f_\mu$ 运行式 (11.40)（$r=0$），步长 $\alpha=1/L_\mu$，$L_\mu=L_\psi+\|\boldsymbol{A}\|^2/(\mu\sigma)$。给定 $\varepsilon>0$，取

$$\mu=\frac{\varepsilon}{2D}, \tag{11.67}$$

则当

$$T+1\ge 2R\sqrt{\frac{L_\psi}{\varepsilon}}+\frac{2\sqrt{2}\,R\|\boldsymbol{A}\|}{\varepsilon}\sqrt{\frac{D}{\sigma}} \tag{11.68}$$

时，$F(\boldsymbol{x}^{(T)})-F^\star\le\varepsilon$。

证明 由定理 11.17，F_μ 是凸函数，梯度 L_μ-Lipschitz 连续。由定理 11.12取 $\boldsymbol{z}=\boldsymbol{x}^\star$，

$$F_\mu(\boldsymbol{x}^{(T)})-F_\mu(\boldsymbol{x}^\star)\le\frac{2L_\mu R^2}{(T+1)^2}.$$

代入式 (11.66)，取 $\mu=\varepsilon/(2D)$ 使偏差为 $\varepsilon/2$，只需

$$(T+1)^2\ge\frac{4L_\mu R^2}{\varepsilon}=\frac{4R^2L_\psi}{\varepsilon}+\frac{8R^2D\|\boldsymbol{A}\|^2}{\sigma\varepsilon^2}.$$

用 $\sqrt{a+b}\le\sqrt{a}+\sqrt{b}$ 开方，即得式 (11.68)。 ■

第一项是光滑部分的成本，第二项 $O(1/\varepsilon)$ 来自平滑。它比次梯度法的 $O(1/\varepsilon^2)$ 好一个量级，代价是必须知道最大值的结构，并能求 $\boldsymbol{u}_\mu$，所以这不违反黑箱下界。

用三段折线代入，$\psi=0$，$\varepsilon=0.1$，$D=\ln 3$，$\max_i a_i^2=4$，$\sigma=1$，初始距离 $R=4$。先算平滑参数和光滑常数，

$$\mu=\frac{0.1}{2\ln 3}\approx 0.0455,\qquad L_\mu=\frac{4}{\mu}\approx 87.9.$$

代入定理，步数上界为

$$T+1\ge 2R\sqrt{L_\mu/\varepsilon}\approx 237.$$

次梯度法的上界 $R^2G^2/\varepsilon^2=16\cdot 4/0.01=6400$，这是相对同一个 ε 的比较。

联合选参数 式 (11.66)说明步长、平滑参数和停止阈值都不能单独选。μ 减小时偏差变小，L_μ 变大，步长 $1/L_\mu$ 变小。停止阈值设得比 μD 小很多没有意义，因为剩下的误差由偏差主宰；设得比 μD 大，又浪费了平滑的精度。上面的取法 $\mu D=\varepsilon/2$ 就是让两者各占一半。

固定一个很小的 μ 从头跑，前期 L_μ 大、步长小，推进很慢。实践中常用逐阶段减小 μ 的办法：先用大的 μ 求解，把结果作为下一阶段的起点，μ 减半，直到目标值。这时有两点必须同步：每一次改变 μ，步长必须按新的 L_μ 更新，否则旧步长可能超过 $1/L_\mu$，上一节的一步不等式不再成立；外推参数 θ 也要重置，因为不同阶段实际上是不同的目标函数。

图 11.22(b) 中，逐阶段的方案（紫色虚线）前几十步明显领先；三种方法达到 $\varepsilon=0.02$ 所用的步数分别约为次梯度法 207、固定小 μ 的加速法 76、逐阶段方案 98。这个小例子上后两者相差不大，差别主要在前期，具体的阶段长度也会影响结果。

替代目标下降不代表原目标下降 梯度方法在 F_μ 上下降，原目标却可能上升。用三段折线，$\mu=1$，$\alpha=\mu/4$，从原问题的最优解 $x^{(0)}=0$ 出发，由前面算出的 $f_1'(0)\approx -0.195$，

$$x^{(1)}\approx 0.049.$$

11.1 次微分
11.2 次梯度方法
11.3 邻近方法
11.4 复合优化
11.5 光滑化
11.6 代理模型
11.6.1 MM 方法
11.6.2 束方法
11.7 本章小结

原目标从最小值 0 升到约 0.024，替代目标（归一化版本）则从约 −0.381 降到约 −0.390。图 11.23是这一过程的全貌：替代问题的最小点不在原问题的解上，迭代朝前者走，原目标一路上升到某个水平。这个上升不超过偏差上界。

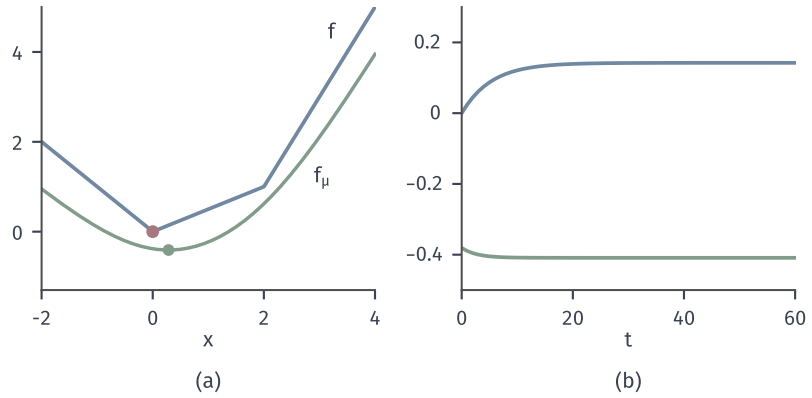


图 11.23 替代目标下降时原目标可以上升。三段折线，$\mu = 1$，$\alpha = \frac{1}{4}$，从原问题的解（红点）出发。(a) 蓝线是 f，绿线是 f_μ，绿点是 f_μ 的最小点。(b) 蓝线是原目标值，单调上升到平台；绿线是替代目标值，单调下降。

所以光滑化方法要同时记录原目标值，并由式 (11.66)判断最终结果。这是光滑化与邻近方法的一个重要差别：邻近方法每轮都直接面对原目标 F。

11.6 代理模型

光滑化一开始就把目标换掉，此后只和替代函数打交道。本节考虑另一种做法：目标不换，每一轮在当前点围绕它造一个容易求解的**代理模型**（surrogate model），用模型的解作为候选更新。问题是：模型什么时候能代表原目标取得进展？

模型易解并不说明什么，关键是模型和原目标是什么关系。第 11.6.1小节的模型处处在原目标上方，解了就直接下降。第 11.6.2小节的模型处处在下方，只能预测，候选点要回到原目标上检验。

11.6.1 MM 方法

回顾邻近梯度法。式 (11.33)的模型在 $\alpha \le 1/L$ 时处处不低于 F，在当前点与 F 相等，而模型的最小点至少不高于当前值，这三条保证了下降。把这三条抽出来，就不必是二次上界了。

定义 11.19　上界代理与 MM 更新　设 $F:\mathbb{R}^n\to\mathbb{R}\cup\{+\infty\}$，$\boldsymbol{x}^{(t)}\in\operatorname{dom}F$。函数 $Q(\cdot\mid\boldsymbol{x}^{(t)})$ 若满足

$$Q(\boldsymbol{x}\mid\boldsymbol{x}^{(t)})\ge F(\boldsymbol{x})\qquad\text{对所有 }\boldsymbol{x},\tag{11.69}$$

$$Q(\boldsymbol{x}^{(t)}\mid\boldsymbol{x}^{(t)})=F(\boldsymbol{x}^{(t)}),\tag{11.70}$$

就称为 F 在 $\boldsymbol{x}^{(t)}$ 处的**上界代理**（majorizer）。选取满足下式的新点，

$$Q(\boldsymbol{x}^{(t+1)}\mid\boldsymbol{x}^{(t)})\le Q(\boldsymbol{x}^{(t)}\mid\boldsymbol{x}^{(t)}),\tag{11.71}$$

这样的迭代称为**MM 方法**（majorization-minimization）。

三项要求合起来给出一串不等式：

$$F(\boldsymbol{x}^{(t+1)})\le Q(\boldsymbol{x}^{(t+1)}\mid\boldsymbol{x}^{(t)})\le Q(\boldsymbol{x}^{(t)}\mid\boldsymbol{x}^{(t)})=F(\boldsymbol{x}^{(t)}).\tag{11.72}$$

第一步用上界，第二步用子问题的进展，第三步用接触。所以不需要精确地求最小点，只需要代理值不升。F 不要求凸，也不要求可微。式 (11.72)的三处都不能少：若只有 $\boldsymbol{x}^{(t)}$ 附近上界成立，第一步在远处就失败，候选点要限制在有效区域内；若模型只在当前点相切而不高于 F，比如凸函数的切线，第一步方向就反了。

可以把上界代理想成在地形上方铺一块柔软的毯子，毯子在脚下贴住地面。把毯子的最低点作为下一步，地面只会比毯子更低，脚下的地面就下降了。

例：绝对值和的二次上界　要最小化 $F(x)=\sum_i|x-y_i|$，也就是求中位数。把每个绝对值换成二次上界。对 $c\neq0$，由 $(|r|-|c|)^2\ge0$，

$$|r|\le\frac{r^2}{2|c|}+\frac{|c|}{2},\tag{11.73}$$

并且 $r=\pm c$ 时取等号。对每一项取 $c=x^{(t)}-y_i$，得到代理

$$Q(x\mid x^{(t)})=\sum_i\Big(\frac{(x-y_i)^2}{2|x^{(t)}-y_i|}+\frac{|x^{(t)}-y_i|}{2}\Big).$$

代理是二次函数，最小点是加权平均：

$$x^{(t+1)}=\frac{\sum_i w_i y_i}{\sum_i w_i},\qquad w_i=\frac{1}{|x^{(t)}-y_i|}.\tag{11.74}$$

这种由当前残差定权重、解加权最小二乘的方法称为**迭代重加权最小二乘**（iteratively reweighted least squares，IRLS）。

用数据 $y = (0, 1, 5)$，从 $x^{(0)} = 3$ 开始。此时 $F(3) = 7$，三个权重是 $(\frac{1}{3}, \frac{1}{2}, \frac{1}{2})$，由式 (11.74)，

$$x^{(1)} = \frac{0 + \frac{1}{2} + \frac{5}{2}}{\frac{4}{3}} = \frac{9}{4}, \qquad F(x^{(1)}) = 6.25.$$

第二轮的权重变成 $(\frac{4}{9}, \frac{4}{5}, \frac{4}{11})$，

$$x^{(2)} \approx 1.628, \qquad F(x^{(2)}) \approx 5.628.$$

继续下去依次是 $x^{(3)} \approx 1.229$ 和 $x^{(4)} \approx 1.045$，F 逐轮降到最优值 5，最优解是中位数 1。靠近中位数的数据点权重越来越大，第四轮权重已经约为 22，这正是非光滑的尖点在代理里的反映。

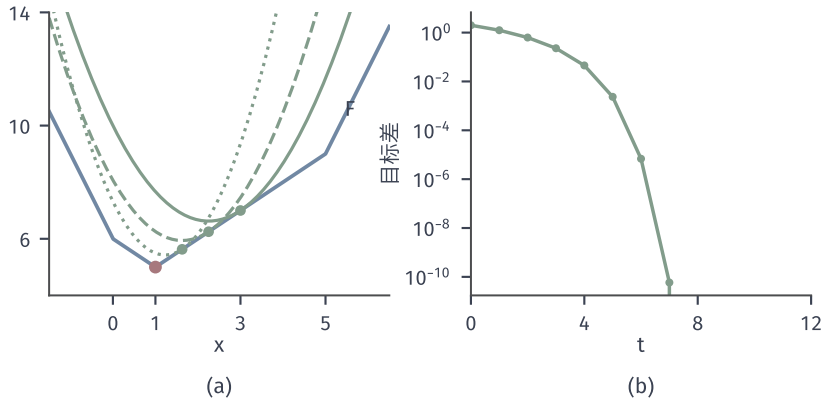


图 11.24　中位数问题的 MM 迭代，$F(x) = |x| + |x-1| + |x-5|$，$x^{(0)} = 3$。(a) 蓝线是 F，绿色实线、虚线、点线是前三轮的二次代理，绿点是接触点，红点是最优解。(b) 目标差（对数坐标）逐轮下降。

图 11.24(a) 显示每条代理都贴住当前点，并处处在 F 上方。这里也有一个需要小心的地方：当前点若恰好落在某个 y_i 上，$c = 0$，式 (11.73)没有定义。常用的修正把权重改成 $1/\max\{|x^{(t)} - y_i|, \delta\}$。容易误解的是，修正后的代理不再是 $|r|$ 的上界，而是 Huber 函数 $h_\delta(r)$ 的上界：函数 $s \mapsto h_\delta(\sqrt{s})$ 对 $s \geq 0$ 是凹的，取切线就得到这个权重。所以修正后的迭代求解的是第 11.5.1小节的替代目标，这时需要按第 11.5.4小节计入偏差。

目标下降与收敛到最优解的区别　式 (11.72)只说目标值不增。F 有下界时目标值序列收敛，但它收敛到什么地方，要看 F 本身。

用一个非凸的稀疏罚函数说明。设

$$F(x) = \frac{1}{2}(x-3)^2 + \frac{7}{2}\ln(1 + |x|). \tag{11.75}$$

函数 $s \mapsto \ln(1+s)$ 在 $s \ge 0$ 上是凹的，所以在当前点取切线就是上界。把 $\ln(1+|x|)$ 换成这个上界，代理为

$$Q(x \mid c) = \frac{1}{2}(x-3)^2 + \frac{7}{2}\Big(\ln(1+|c|) + \frac{|x|-|c|}{1+|c|}\Big).$$

代理是一个带绝对值的二次函数，最小点由软阈值给出：

$$x^{(t+1)} = S_{\tau^{(t)}}(3), \qquad \tau^{(t)} = \frac{7/2}{1+|x^{(t)}|}. \tag{11.76}$$

从 $x^{(0)} = 1$ 出发，阈值依次是 1.75，1.556，1.432，序列是

$$1,\ 1.25,\ 1.444,\ 1.568,\ \ldots \to 1 + \frac{\sqrt{2}}{2} \approx 1.707,$$

目标值从 4.426 单调下降到约 4.321。从 $x^{(0)} = 0.2$ 出发，阈值是 2.917, 3.231，序列是

$$0.2,\ 0.083,\ 0,\ 0,\ \ldots$$

目标值从 4.558 单调下降到 4.5，然后停住。$x = 0$ 是一个局部最小点：F 在此处的右导数是 $-3+3.5 > 0$，左导数是 $-3-3.5 < 0$，代理的阈值 3.5 也比数据 3 大。

两条序列都满足不等式链，一条到达全局最优值 4.321，另一条停在 4.5。图 11.25显示了这两个吸引域。

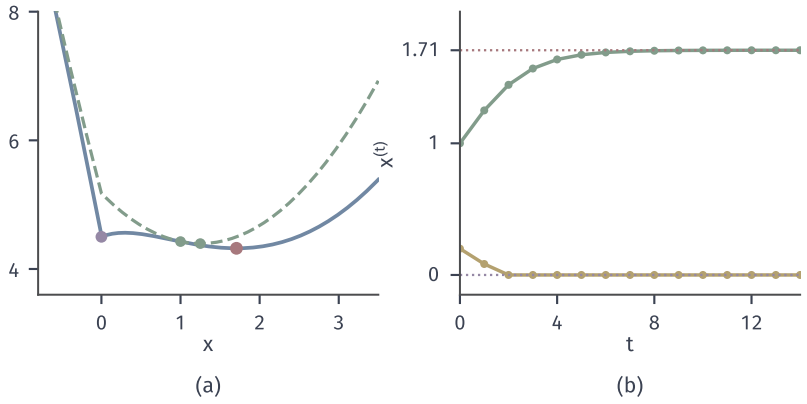


图 11.25　MM 在非凸目标上的两个结局，目标是式 (11.75)。(a) 蓝线是 F，绿色虚线是 $x=1$ 处的代理，绿点是接触点和代理的最小点。红点是全局最优解，紫点是另一个局部最优解 $x=0$。(b) 迭代序列，绿线从 1 出发到全局最优解，黄线从 0.2 出发停在局部最优解。

要把目标值收敛提升到“极限点是驻点”，还需要额外的条件：常见的要求是代理与原目标在接触点的方向导数一致，代理随当前点连续变化，

11.1 次微分
11.2 次梯度方法
11.3 邻近方法
11.4 复合优化
11.5 光滑化
11.6 代理模型
11.6.1 MM 方法
11.6.2 束方法
11.7 本章小结

子问题的解足够接近代理的最小点。要说全局最优，还得有凸性。MM 的优点是简单和单调，没有给出离最优值还有多远。

11.6.2 束方法

次梯度法每步用一条支撑线，用完就丢了。对凸目标，每一条支撑线都是全局的下界，丢掉很可惜。**束方法**（bundle method）把读到的支撑线都留下，拼成一个下界模型。

主要思想 设 $f:\mathbb{R}^n\to\mathbb{R}$ 是凸函数，读取程序在点 $\boldsymbol{y}$ 返回函数值和一个次梯度。假设已经在 $\boldsymbol{y}^{(0)},\dots,\boldsymbol{y}^{(t)}$ 处读到次梯度 $\boldsymbol{g}_0,\dots,\boldsymbol{g}_t$，由支撑不等式，

$$m^{(t)}(\boldsymbol{x})=\max_{0\le j\le t}\bigl\{f(\boldsymbol{y}^{(j)})+\langle \boldsymbol{g}_j,\boldsymbol{x}-\boldsymbol{y}^{(j)}\rangle\bigr\}\le f(\boldsymbol{x}). \tag{11.77}$$

这个分段线性模型称为**割平面模型**（cutting-plane model），读到的这一组支撑线合称束。它在读过的点上等于 f，别处低估 f。

直接最小化 $m^{(t)}$ 不行。开始时模型只有一条直线，根本没有最小点；后面它的最小点也可能远远地落在信息不足的地方。解决办法是设一个**稳定中心**（stability center）$\hat{\boldsymbol{x}}^{(t)}$，表示目前已确认的好点，加一个距离项把候选点拉在中心附近：

$$\boldsymbol{y}^{(t+1)}=\arg\min_{\boldsymbol{x}}\Bigl\{m^{(t)}(\boldsymbol{x})+\frac{1}{2\tau}\|\boldsymbol{x}-\hat{\boldsymbol{x}}^{(t)}\|_2^2\Bigr\},\qquad \tau>0. \tag{11.78}$$

这是模型的邻近映射 $\operatorname{prox}_{\tau m^{(t)}}(\hat{\boldsymbol{x}}^{(t)})$，解存在且唯一。引入变量 v 表示模型值，子问题是一个小的二次规划：最小化 $v+\|\boldsymbol{x}-\hat{\boldsymbol{x}}^{(t)}\|_2^2/(2\tau)$，约束是 v 不低于束中每条支撑线在 $\boldsymbol{x}$ 处的值。

接受还是拒绝 模型预测下降

$$\delta^{(t)}=f(\hat{\boldsymbol{x}}^{(t)})-m^{(t)}(\boldsymbol{y}^{(t+1)}). \tag{11.79}$$

因为子问题在 $\hat{\boldsymbol{x}}^{(t)}$ 处的值就是 $f(\hat{\boldsymbol{x}}^{(t)})$（中心处的支撑线在束内），而 $\boldsymbol{y}^{(t+1)}$ 是子问题的最小点，所以 $\delta^{(t)}\ge 0$。但模型是下界，预测往往偏乐观，必须用原目标检验。给定 $\beta\in(0,1)$，判断

$$f(\hat{\boldsymbol{x}}^{(t)})-f(\boldsymbol{y}^{(t+1)})\ge\beta\,\delta^{(t)}. \tag{11.80}$$

式 (11.80)成立就把中心移到候选点，称为**实质步**（serious step）；否则中心不动，称为**空步**（null step）。两种情况都把 $\boldsymbol{y}^{(t+1)}$ 处的新支撑线加入束。

实质步是有效的移动，空步是对模型的改进。空步没有白费，它恰好在模型低估最严重的地方补上一条割线，下一次预测就准了。这是束方法和前面的方法的一个显著差别：不是每一步都移动，但每一步都学到东西。

计算过程 用三段折线 $f(x)=\max\{-x, x/2, 2x-3\}$，$\tau=2$，$\beta=\frac{1}{2}$。

变量

- 束：列表 $\{(\boldsymbol{y}^{(j)}, f(\boldsymbol{y}^{(j)}), \boldsymbol{g}_j)\}$。
- $\hat{\boldsymbol{x}}^{(t)}$：稳定中心；$\delta^{(t)}$：预测下降。
- τ，β，容差 ε。

初始化 选 $\boldsymbol{y}^{(0)}$，读取 f 和一个次梯度，令 $\hat{\boldsymbol{x}}^{(0)}=\boldsymbol{y}^{(0)}$。例中 $y^{(0)}=4$，$f(4)=5$，$g_0=2$。

每轮更新

1. 由式 (11.78)解候选点。例中第一轮模型只有一条直线，

$$m^{(0)}(x)=2x-3, \qquad y^{(1)}=4-2\tau=0.$$

2. 由式 (11.79)算预测下降；若 $\delta^{(t)}\le\varepsilon$，停止，返回 $\hat{\boldsymbol{x}}^{(t)}$。例中第一轮

$$\delta^{(0)}=5-(-3)=8.$$

3. 读取 $f(\boldsymbol{y}^{(t+1)})$ 和次梯度，加入束。例中第一轮

$$f(0)=0, \qquad g_1=\frac{1}{2}.$$

4. 由式 (11.80)决定是否移动中心。例中第一轮实际下降是 $5\ge\frac{1}{2}\cdot 8$，实质步，中心移到 0。

   第二轮的模型多了一条直线，$m^{(1)}(x)=\max\{2x-3,\ x/2\}$。中心在 0，子问题的解在 $x/2$ 这一支上，令 $\frac{1}{2}+x/2=0$，得到

$$y^{(2)}=-1, \qquad m^{(1)}(-1)=-\frac{1}{2}, \qquad \delta^{(1)}=\frac{1}{2}.$$

   实际 $f(-1)=1$，比中心 $f(0)=0$ 还高，实际下降是 -1，小于 $\beta\delta^{(1)}=\frac{1}{4}$，是空步，中心不动。把 $x=-1$ 处斜率 -1 的支撑线 $-x$ 加入束。

第三轮模型变成 $\max\{2x-3,\ x/2,\ -x\}$，在中心 0 的次微分是 $[-1, \frac{1}{2}]$，包含 0，所以 $y^{(3)}=0$，

$$\delta^{(2)}=0.$$

预测下降为零，停止，最终得到 $\hat{x}=0$，也就是最优解。图 11.26逐轮画出了模型：(b) 的模型过分乐观，(c) 补上割线后预测就准了。

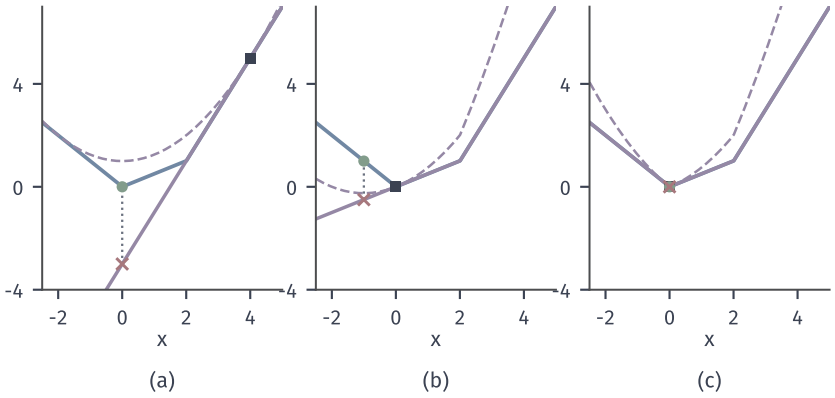


图 11.26　束方法在三段折线上的三轮，$\tau=2$。蓝线是 f，紫色实线是割平面模型，紫色虚线是模型加距离项，黑方块是稳定中心。红叉是候选点处的模型值，绿点是候选点处的真实目标值。(a) 第一轮，实质步。(b) 第二轮，候选点 -1 处模型偏低，真实目标值反而高，空步。(c) 第三轮，候选点就是中心，预测下降为零，停止。

评价原目标的误差　预测下降 $\delta^{(t)}$ 既用于接受判断，也是一个停止证书。子问题的最优性条件给出

$$\boldsymbol{s}^{(t)}=\frac{\hat{\boldsymbol{x}}^{(t)}-\boldsymbol{y}^{(t+1)}}{\tau}\in\partial m^{(t)}(\boldsymbol{y}^{(t+1)}).$$

由模型是 f 的下界和 $\boldsymbol{s}^{(t)}$ 是模型的次梯度，对任意 $\boldsymbol{x}$，

$$f(\boldsymbol{x})\ge m^{(t)}(\boldsymbol{x})\ge m^{(t)}(\boldsymbol{y}^{(t+1)})+\langle \boldsymbol{s}^{(t)},\boldsymbol{x}-\boldsymbol{y}^{(t+1)}\rangle.$$

由式 (11.79)替换模型值，再用 $\boldsymbol{s}^{(t)}$ 的定义把候选点写成 $\hat{\boldsymbol{x}}^{(t)}$ 减 $\tau\boldsymbol{s}^{(t)}$，整理后得到

$$f(\boldsymbol{x})\ge f(\hat{\boldsymbol{x}}^{(t)})+\langle \boldsymbol{s}^{(t)},\boldsymbol{x}-\hat{\boldsymbol{x}}^{(t)}\rangle-e^{(t)},\qquad e^{(t)}=\delta^{(t)}-\tau\|\boldsymbol{s}^{(t)}\|_2^2. \tag{11.81}$$

取 $\boldsymbol{x}=\hat{\boldsymbol{x}}^{(t)}$ 得 $e^{(t)}\ge 0$，所以 $\tau\|\boldsymbol{s}^{(t)}\|_2^2\le\delta^{(t)}$，$e^{(t)}\le\delta^{(t)}$。式 (11.81)说 $\boldsymbol{s}^{(t)}$ 是一个带误差 $e^{(t)}$ 的近似次梯度。设中心到某个最优解的距离不超过 R，在式中取 $\boldsymbol{x}=\boldsymbol{x}^\star$，得到

$$f(\hat{\boldsymbol{x}}^{(t)})-f^\star\le e^{(t)}+R\|\boldsymbol{s}^{(t)}\|_2\le\delta^{(t)}+R\sqrt{\frac{\delta^{(t)}}{\tau}}. \tag{11.82}$$

这个界每一轮都可以直接计算，不需要任何收敛定理。例中第三轮 $\delta^{(2)} = 0$，$\boldsymbol{s}^{(2)} = 0$，这一轮的证书说明误差为零。

收敛与成本 在凸目标、次梯度有界的条件下，邻近束方法的中心目标值收敛到 $f^\star$，实质步无穷多和有限多两种情形要分别讨论，证明篇幅较长。这里强调它的成本结构。

图 11.27在平面上比较束方法与次梯度法，横轴是原目标的读取次数。束方法只用很少几次读取就到达很高的精度，这得益于分段线性目标正好是割平面模型的同类，代价是每轮要解一个二次规划，约束个数随束增长。实践中会合并或丢弃不活跃的割线，这需要额外的规则来保证模型仍然有效。

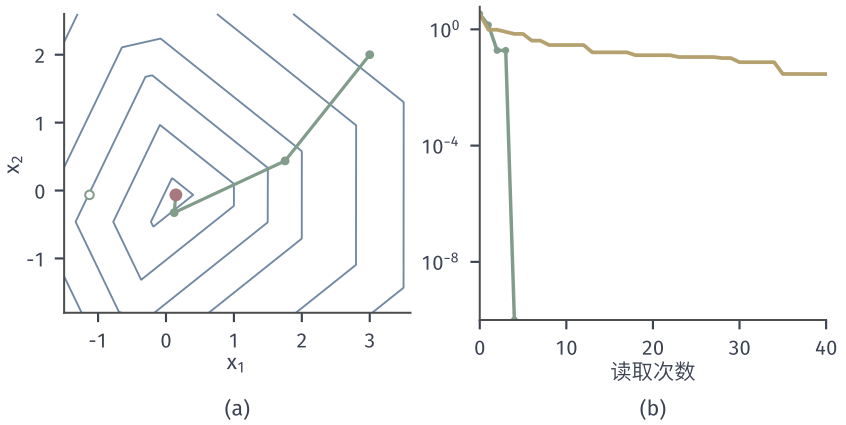


图 11.27 束方法与次梯度法，目标与图 11.22相同，$\boldsymbol{x}^{(0)} = (3, 2)$。(a) 蓝线是等高线，红点是最优解，绿色实心点和折线是实质步，空心圆是空步的候选点。(b) 绿线是束方法的中心目标差，黄线是次梯度法的最好目标差（步长 $\sqrt{13}/\sqrt{t+1}$），横轴是原函数读取次数，纵轴为对数坐标。

上界模型与下界模型 两种模型提供的信息不同，表 11.5把它们和前面的光滑化放在一起比较。上界模型给出保证而无需再读原目标，但不告诉离最优有多远。下界模型给出离最优的证书，但每步都要检验。把下界模型的解直接当作进展，或者把上界模型的最小值当作下界，都是错误的用法。

	MM	束方法	光滑化
辅助函数	上界，每轮重建	下界，逐轮累加	固定的光滑替代
与原目标的关系	处处在上方	处处在下方	相差不超过 μD
接受规则	代理值不增	实际下降够大	无
原目标逐轮	不增	中心不增	可以上升
误差证书	无	式 (11.82)	式 (11.66)
主要成本	代理子问题	二次规划	梯度次数

表 11.5 三种辅助模型的对照。

11.1 次微分
11.2 次梯度方法
11.3 邻近方法
11.4 复合优化
11.5 光滑化
11.6 代理模型
11.7 本章小结

11.7 本章小结

本章从一个具体的麻烦开始：Lasso 的解恰好落在目标不可微的地方。为此先用支撑直线的斜率定义了次梯度和次微分，凸目标的最优解由 $\mathbf{0} \in \partial f$ 充要地刻画；和与复合的规则需要相对内部这样的正则条件。非凸函数上要改用局部定义的广义导数，那时的条件只是必要的。

此后各节回答“用什么信息推进迭代”，答案不同，要求和保证也不同。

次梯度法只用支撑信息，每步一个次梯度，单步不一定下降，但距离的递推使平均点或最好点的目标差为 $O(1/\sqrt{T})$，这在黑箱模型下不能本质改进。

邻近方法把难求导的结构留在子问题里。复合目标的邻近梯度法（ISTA）在凸情形达到 $O(1/T)$，FISTA 用外推达到 $O(1/T^2)$，后者不要求逐轮下降，也不能直接用于非凸目标；非凸情形用映射残差评价，残差为零只说明是复合驻点。邻近方法的前提是邻近映射可算，映射可定义、子问题可计算和原问题收敛是三件要分别核对的事。

光滑化和代理模型改变每一步要解的问题。Huber 函数是绝对值的 Moreau 包络，Nesterov 平滑利用最大值结构在内层加强凸项，它们用偏差 μD 换取 $O(1/\mu)$ 的光滑常数，原目标的误差由偏差和求解误差两部分决定；平滑改变目标，加速改变迭代规则，配合使用可得 $O(1/\varepsilon)$ 的总步数。MM 用上界代理保证原目标不增，束方法用支撑线拼成的下界模型预测下降，并用接受规则和预测下降值来评价真实进展。

方法	需要的结构	凸情形的保证
次梯度法	次梯度有界	目标差 $O(1/\sqrt{T})$
邻近点法	$\operatorname{prox}_{\alpha f}$ 可算	目标差 $O(1/\sum \alpha^{(t)})$
ISTA	∇f，$\operatorname{prox}_{\alpha r}$	目标差 $O(1/T)$，单调
FISTA	同上	目标差 $O(1/T^2)$，不单调
平滑加速	最大值结构，内层可解	$O(1/\varepsilon)$ 步，带偏差 μD
MM	上界代理	目标值不增
束方法	次梯度，二次规划求解	可计算的误差证书

表 11.6 本章方法的对照。T 为迭代步数，ε 为原目标精度。

表 11.6把这些方法放在一起。本章全部在无约束或简单约束下讨论，一般约束的乘子、增广 Lagrange 函数与 ADMM 由第 22章结合约束结构建立；按变量分块使用邻近映射的方法见第 12章。

第四部分

分块优化

Block Optimization

阅读指引

许多问题的变量维数很高，但固定其余变量后，只对一部分变量求解却很便宜。按块更新正是利用这一点：每次只动一块变量，用较小的代价换取完整目标的进展。

第 12章先建立块坐标下降的共同框架，比较循环、随机和贪心的选块方式，再按块内的计算手段组织算法：精确求解条件子问题、最小化局部模型、使用块邻近更新以及交替求解矩阵因子。逐块最优并不等于整体最优，章中用反例说明这一差距，并给出保证完整目标进展所需要的条件。

12.1 分块问题
12.1.1 块的划分
12.1.2 块间耦合
12.2 块坐标下降（BCD）
12.3 局部近似更新
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.8 本章小结

第 12 章

分块优化

设想一个有一百万列的最小二乘问题。每算一次完整梯度，都要把矩阵的全部元素读一遍。如果其他变量都不动，只调整一个系数，那么最优的调整量只用这一列就能算出来。再设想把一张评分表分解成两个因子的乘积：同时求两个因子是非凸问题，但固定其中一个，另一个就是普通的最小二乘。两个问题有同一个特点：变量合在一起很难处理，拆开之后每一部分都便宜。

本章研究这种“每次只处理一部分变量”的做法。核心问题有两个：只动一部分变量，能不能保证完整目标取得进展？这样省下来的计算，会不会被更多的迭代次数抵消？

第 12.1节先说明怎样划分变量，以及哪些耦合会让逐块更新寸步难行。第 12.2节以精确求解一块为基准，建立选块的三种规则。精确求解常常太贵，第 12.3节改用局部模型，并给出加速和曲率的版本。第 12.4节研究变量自然分成少数几组的情形，以矩阵分解为主例，同时看到逐块最优的局限。

这些方法看上去各不相同，第 12.5节用“块上界”解释它们中的一大部分为什么能下降，第 12.6节把这一想法用到带非光滑项的目标上。第 12.7节把算法放回实际计算：并行时步长怎样改，子问题要解到多准，各种保证分别回答什么问题，总工作量是否真的减少。

12.1 分块问题

本节回答一个问题：把变量分成若干块、每次只动一块时，块应当怎样划分，块与块之间的哪些关系会妨碍这种做法。

12.1.1 块的划分

两个具体的问题　先看最小二乘。设 $\boldsymbol{A} \in \mathbb{R}^{N\times n}$，第 j 列记为 $\boldsymbol{a}_j$，目标是

$$f(\boldsymbol{x}) = \frac{1}{2}\|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|_2^2.$$

若其他系数不动，只改 x_j，残差 $\boldsymbol{r} = \boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}$ 只沿 $\boldsymbol{a}_j$ 变化。这时一列数据就够用，变量的一个分量自然成为一块。

再看矩阵分解。给定 $\boldsymbol{Y} \in \mathbb{R}^{p\times q}$，寻找 $\boldsymbol{U} \in \mathbb{R}^{p\times r}$、$\boldsymbol{V} \in \mathbb{R}^{q\times r}$，使 $\boldsymbol{U}\boldsymbol{V}^{\top}$ 接近 $\boldsymbol{Y}$，目标是

$$\|\boldsymbol{Y} - \boldsymbol{U}\boldsymbol{V}^{\top}\|_F^2.$$

这里最自然的一块不是单个元素，而是整个因子。固定 $\boldsymbol{V}$ 后，目标关于 $\boldsymbol{U}$ 是凸二次的，可以一次解出。

块与条件子问题　两个例子的共同结构是：把坐标分成互不重叠的几组，每次只让一组变化。为了精确地谈论这件事，需要一套记号。

> **定义 12.1　变量分块与条件子问题**　把下标集 $\{1,\dots,n\}$ 划分为 B 个互不相交的非空子集 $J_1,\dots,J_B$，每个子集称为一个**变量块**（variable block）。对块 J，记 $\boldsymbol{x}_J \in \mathbb{R}^{|J|}$ 为 $\boldsymbol{x}$ 在 J 上的分量，$\boldsymbol{U}_J \in \mathbb{R}^{n\times|J|}$ 为单位矩阵中由 J 对应的列组成的子矩阵，并记偏梯度
>
> $$\nabla_J f(\boldsymbol{x}) = \boldsymbol{U}_J^{\top}\nabla f(\boldsymbol{x}). \tag{12.1}$$
>
> 固定 $\boldsymbol{x}$ 在其他块上的取值，把块 J 的取值换成 $\boldsymbol{z}$，得到的函数
>
> $$\varphi_J(\boldsymbol{z};\boldsymbol{x}) = f\big(\boldsymbol{x} + \boldsymbol{U}_J(\boldsymbol{z} - \boldsymbol{x}_J)\big) \tag{12.2}$$
>
> 称为块 J 的**条件函数**（conditional function），在块 J 的允许集合上最小化它的问题称为**条件子问题**（conditional subproblem）。

$\boldsymbol{U}_J\boldsymbol{h}$ 的作用是把长度为 $|J|$ 的向量 $\boldsymbol{h}$ 放回块 J 的位置，其余分量补零。单个坐标是块大小为 1 的特殊情形，下文的结论同时覆盖单坐标和多坐标的块。图 12.1(a) 是这种划分的样子：绿色的一段正在变化，其余两段被固定。

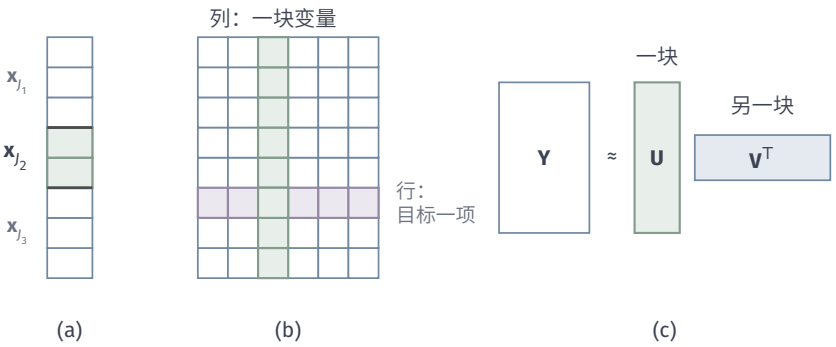


图 12.1 变量分块的三种形式。(a) 向量 $\boldsymbol{x}$ 分成三块，绿色的块 J_2 正在更新，其余块固定。(b) 最小二乘的数据矩阵：选一列（绿）是选一块变量；选一行（紫）是选目标的一项，后者不属于本章的做法。(c) 矩阵分解中，整个因子 $\boldsymbol{U}$ 是一块。

图 12.1(b) 还指出了一个容易混淆的区别。选列是在变量上做选择，读到的偏导数是准确的；选行是在目标的求和项上做选择，读到的方向只是全梯度的一个估计。两种选择回答不同的问题，也可以组合使用。选行带来的方向误差留到第 13章研究，本章的偏梯度都是精确的。

贯穿本章的例子 全章反复使用同一个带交叉项的二元二次目标，起点固定为 $(3,4)$：

$$f(\boldsymbol{x}) = x_1^2 + x_1 x_2 + x_2^2, \qquad \boldsymbol{x}^{(0)} = (3,4). \tag{12.3}$$

它的梯度和 Hessian 分别是

$$\nabla f(\boldsymbol{x}) = \begin{bmatrix} 2x_1 + x_2 \\ x_1 + 2x_2 \end{bmatrix}, \qquad \boldsymbol{Q} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

$\boldsymbol{Q}$ 的特征值是 1 和 3，所以强凸常数 $\mu = 1$，光滑常数 $L = 3$，唯一的最优解是原点，$f^\star = 0$。起点的目标值是

$$f(\boldsymbol{x}^{(0)}) = 9 + 12 + 16 = 37.$$

这个目标也是一个最小二乘问题。取

$$\boldsymbol{A} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}, \qquad \boldsymbol{b} = \boldsymbol{0},$$

则 $\boldsymbol{A}^\top \boldsymbol{A} = \boldsymbol{Q}$，并且 $\frac{1}{2}\|\boldsymbol{A}\boldsymbol{x}\|_2^2$ 展开后正是式 (12.3)。对一般的 $\boldsymbol{b} = \boldsymbol{A}\boldsymbol{x}^\star$，把变量平移成 $\boldsymbol{x} - \boldsymbol{x}^\star$ 就回到 $\boldsymbol{b} = \boldsymbol{0}$，这里取 $\boldsymbol{0}$ 只是为了算起来干净。

一个坐标还是两个一起 现在比较两种走法。按坐标更新时，把 $x_2 = 4$ 固定，条件函数 $z^2 + 4z + 16$ 在 $z = -2$ 取最小，走到 $(-2, 4)$；再固定 $x_1 = -2$，走到 $(-2, 1)$。

联合求解则把两个变量当成一块，解方程 $\boldsymbol{Qx} = \boldsymbol{0}$，一步到达原点。下表记录了目标值，图 12.2是对应的路径。

做法	计算量	走完后的目标值
更新 x_1	一次除法	12
再更新 x_2	一次除法	3
联合求解	解一个 2×2 方程组	0

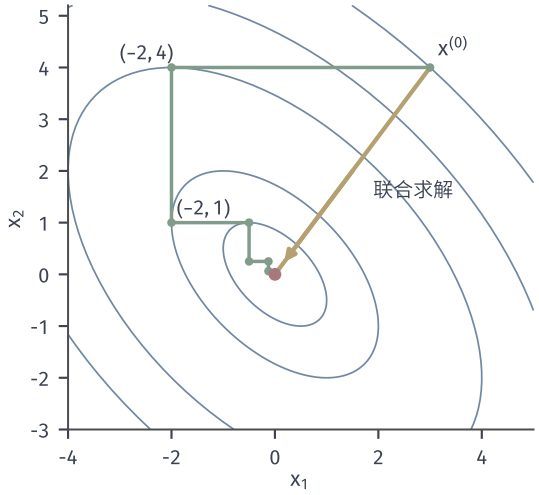


图 12.2 式 (12.3)上坐标更新与联合求解的比较。蓝色是等高线，绿色折线是依次精确更新 x_1、x_2 的前三轮，只能沿坐标轴方向走；黄色箭头是把两个变量当作一块、一步解出的路径；红点是最优解。

块越大，每步的进展越大，但一步也越贵。这个交换关系在高维时才真正显出来。图 12.3取 $n = 64$ 的链式二次目标，Hessian 为三对角矩阵，主对角线上是 2.02，次对角线上是 -1，把相邻的 p 个变量分成一块，依次精确求解。

12.1 分块问题
12.1.1 块的划分
12.1.2 块间耦合
12.2 块坐标下降（BCD）
12.3 局部近似更新
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.8 本章小结

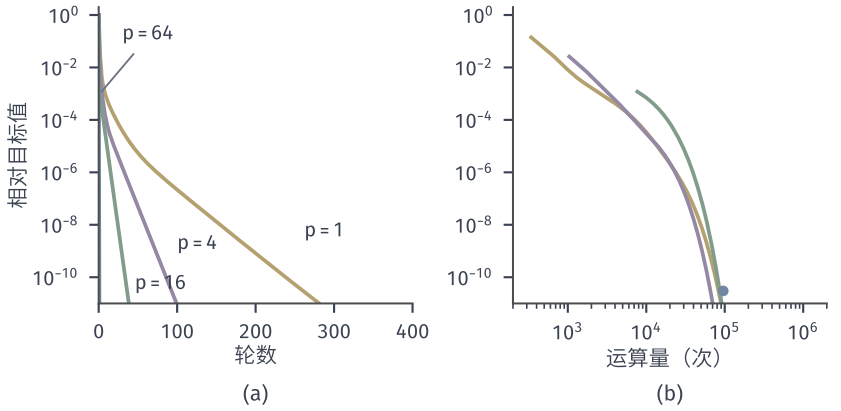


图 12.3 块大小与计算量的交换。目标是 $n = 64$ 的链式二次函数，p 个相邻变量为一块，循环精确更新。(a) 相对目标值随轮数的变化，块越大轮数越少，$p = 64$ 一轮即解出。(b) 同一组数据按运算量画出，颜色与 (a) 相同，运算量按稠密块计：每块一次 Cholesky 分解计 $p^3/3$，每次回代计 $2p^2$，读取耦合项计 $3p$，蓝点是 $p = 64$ 一次解出所用的运算量。

以相对目标值降到 10^{-10} 为准，从 (a) 看，把块从 1 增大到 16，所需轮数从 239 减到 34，好像块越大越好。(b) 把横轴换成运算量后，优势大半消失：四种块大小的总运算量都在 6×10^4 到 10^5 之间，$p = 4$ 反而最少。块大了一轮贵得多，轮数减少的好处被抵消了。选择块大小时，不能只看轮数。

决定块大小的三件事 由此可以归纳出三个需要同时考虑的因素。第一是变量耦合：彼此强耦合的变量放进同一块，块内的联合求解才能消除这种耦合。第二是子问题的求解：块内要有闭式解、可复用的分解或便宜的迭代，否则分块省不下计算。

第三是数据读取：一块对应的数据最好能连续读取，并能借助残差之类的中间量增量维护，否则每次更新一块也要把数据读遍。

无论块怎样划分，评价进展时都看完整目标 f，而不是当前块上条件函数的值。条件函数的最小值只说明这一块调到了最好，并不说明问题解决了。第 12.2.1小节会用数字说明这个区别。

12.1.2 块间耦合

上一小节的耦合只影响速度。有些耦合更严重，它让逐块更新根本走不动。本小节看两种情形，它们决定了后面每个算法都要检查的两个条件：可行性和可分性。

乘积可行域 若可行集是各块集合的乘积

$$\boldsymbol{C} = \boldsymbol{C}_{J_1} \times \cdots \times \boldsymbol{C}_{J_B}, \tag{12.4}$$

每一块只需留在自己的集合内，整个点就是可行的。各块的约束互不牵连，逐块更新可以自由进行。箱式约束 $l_j \le x_j \le u_j$ 是最常见的例子，图 12.4(a) 中沿任一坐标轴移动，只要不越过自己的边界，点就留在矩形内。

耦合约束 情况在约束把几块绑在一起时完全不同。设 $\boldsymbol{x} \in \mathbb{R}^n$ 满足 $\sum_{j=1}^{n} x_j = 1$，可行点 $\boldsymbol{x}$ 的 x_j 改成 $x_j + \delta$，分量之和就变成 $1 + \delta$。所以只要 $\delta \neq 0$ 就不可行，单坐标更新只能停在原地。

要在这个集合内移动，至少同时改两个坐标，让它们的变化互相抵消：

$$x_i \leftarrow x_i + \delta, \qquad x_j \leftarrow x_j - \delta.$$

图 12.4(b) 画出 $n = 3$ 的情形。红色的单坐标方向离开了三角形所在的平面，绿色的两坐标方向留在平面内。

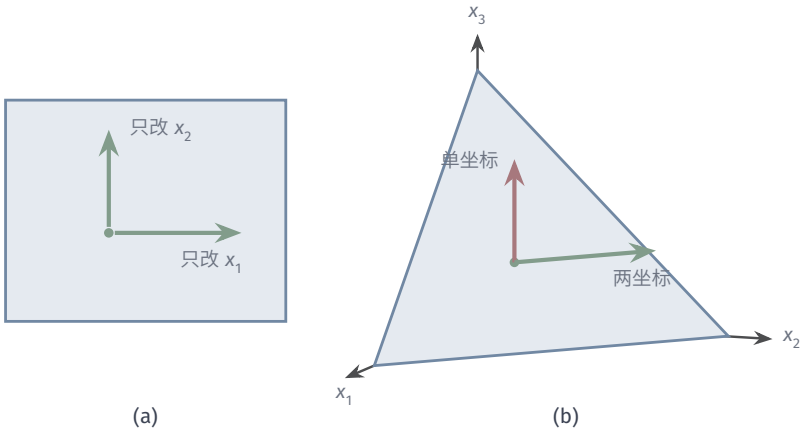


图 12.4 可行域与块的移动。(a) 乘积可行域：矩形内的点沿任一坐标轴移动都可以留在可行域内。(b)$\sum_j x_j = 1$ 的可行点（只画 $x_j \ge 0$ 的部分）：红色的单坐标移动离开平面，变得不可行；绿色的两坐标移动保持分量之和不变。

一般的耦合约束需要借助乘子把它们拆开，这部分内容放在第 22章。本章只讨论乘积可行域。

不可分的非光滑项 另一种障碍来自目标本身。考虑凸函数

$$F(u, v) = 2|u - v| + |u + v - 2|, \tag{12.5}$$

它的最小值在 $(1,1)$ 处取到，$F(1,1)=0$。把点放在原点，$F(0,0)=2$，看两个坐标方向能否改进。

固定 $v=0$，条件函数是 $F(u,0)=2|u|+|u-2|$，分段写出来就是

$$F(u,0)=\begin{cases}2-3u, & u<0,\\ 2+u, & 0\le u\le 2,\\ 3u-2, & u>2.\end{cases}$$

左边斜率为负，右边斜率为正，所以 $u=0$ 是唯一的最小点。由 F 关于 u,v 的对称性，固定 $u=0$ 时 $v=0$ 也是唯一的最小点。

因此从原点出发，两个坐标都不肯动，算法永远停在目标值 2 处。可是沿对角线走却能下降：

$$F(s,s)=2|s-1|,$$

s 从 0 增大到 1 时目标值从 2 降到 0。图 12.5画出了这一情形。

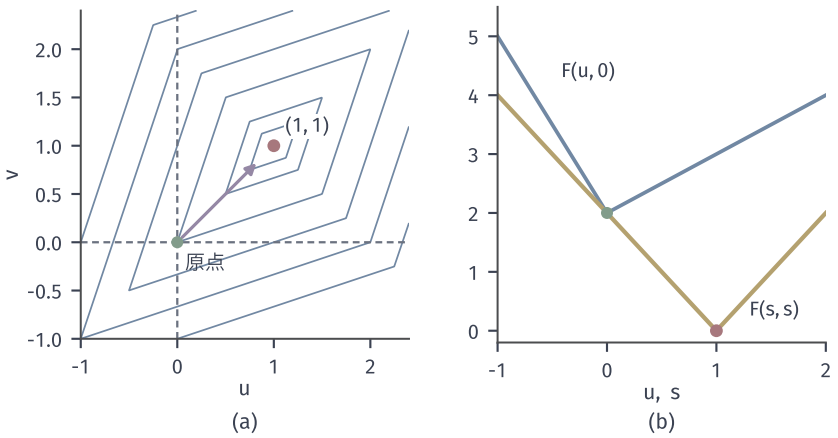


图 12.5　不可分非光滑项造成的坐标停滞。$F(u,v)=2|u-v|+|u+v-2|$。(a) 蓝色是等高线，它们在折线上有尖角。绿点是原点，两条灰色虚线是过原点的坐标方向，紫色箭头指向最优解（红点）。(b) 蓝线是坐标方向上的 $F(u,0)$，在原点取最小；黄线是对角线方向上的 $F(s,s)$，从原点继续下降。

原因在于原点恰好落在折线 $u=v$ 上。原点附近 $u+v-2<0$，于是

$$F(u,v)=2|u-v|+2-u-v.$$

方向 (d_1,d_2) 要下降，必须满足 $2|d_1-d_2|<d_1+d_2$，这些方向夹在 $(3,1)$ 和 $(1,3)$ 之间，是以对角线为中心的一个窄角，两个坐标方向都在窄角之外。

可以想象站在一条斜向的沟底，沿沟走是下坡，朝东西或南北走都会撞上沟壁。这个类比只对应“沿坐标方向不能下降”这一点：沟底是目标的

尖角，光滑的目标没有这样的沟壁。如果 F 可微，两个偏导数都为零意味着梯度为零，这种事就不会发生。

这两种情形提醒我们，后面每个算法都要回答两个问题：只改一块时点还可行吗？非光滑项能按块拆开吗？第 12.4.2小节还会回到这个反例，把“每块都不能改进”与“整体最优”的差别说清楚。

12.1 分块问题
12.2 块坐标下降（BCD）
12.2.1 精确块更新
12.2.2 循环块坐标下降（Cyclic BCD）
12.2.3 随机块坐标下降（RBCD）
12.2.4 贪心块坐标下降（Greedy BCD）
12.3 局部近似更新
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.8 本章小结

12.2 块坐标下降（BCD）

上一节把变量分成了块。接下来要弄清：每次选一块、固定其余变量并改善完整目标，这个过程应当怎样组织？

块坐标下降（block coordinate descent，BCD）把一次迭代拆成两个环节：选块决定这一步动哪一块，块内更新决定这一块怎样动。两个环节可以自由搭配。本节先固定块内更新为“精确求解条件子问题”，集中比较循环、随机、贪心三种选块方式；第 12.3节以后再替换块内更新。

这些选块规则也能用于后面的梯度、邻近或模型更新，但搭配之后的下降和收敛保证要重新核对，不能直接搬用。

12.2.1 精确块更新

更新规则 设可行集是乘积形式 (12.4)，当前点为 $\boldsymbol{x}^{(t)}$，选中块 J。精确块更新在块 J 的允许集合上最小化条件函数，其他块不动：

$$\boldsymbol{x}_J^{(t+1)} \in \arg\min_{\boldsymbol{z}\in\boldsymbol{C}_J} \varphi_J(\boldsymbol{z};\boldsymbol{x}^{(t)}), \qquad \boldsymbol{x}_i^{(t+1)} = \boldsymbol{x}_i^{(t)} \ \ (i \notin J). \tag{12.6}$$

这里的“$\in$”提醒我们最小点可能不止一个。

完整目标不增 这个规则带来的进展来自一个简单的比较：当前的 $\boldsymbol{x}_J^{(t)}$ 本身就是子问题的一个候选，最优解不会比它差。其他块又没有改变，所以条件函数的值就是完整目标的值。

> **引理 12.2 精确块更新的单调性** 设可行集有乘积结构 (12.4)，$\boldsymbol{x}^{(t)} \in \boldsymbol{C}$，且条件子问题的最小点存在。按式 (12.6)更新后 $\boldsymbol{x}^{(t+1)} \in \boldsymbol{C}$，并且
>
> $$f(\boldsymbol{x}^{(t+1)}) \le f(\boldsymbol{x}^{(t)}). \tag{12.7}$$

证明 其他块未变，块 J 落在 $\boldsymbol{C}_J$ 内，乘积结构保证新点可行。$\boldsymbol{x}_J^{(t)} \in \boldsymbol{C}_J$ 是条件子问题的可行点，最小点的函数值不超过它的函数值，于是

$$\varphi_J(\boldsymbol{x}_J^{(t+1)};\boldsymbol{x}^{(t)}) \le \varphi_J(\boldsymbol{x}_J^{(t)};\boldsymbol{x}^{(t)}).$$

由定义 (12.2)，左边等于 $f(\boldsymbol{x}^{(t+1)})$，右边等于 $f(\boldsymbol{x}^{(t)})$。 ■

两件要先核对的事 引理假定最小点存在，这一条并非总成立。取 $f(x_1,x_2)=e^{x_1}+x_2^2$，固定 x_2 后，条件函数沿 $x_1\to-\infty$ 递减而取不到最小值，更新规则根本没有定义。使用精确块更新前，要用条件函数的紧下水平集之类的条件确认最小点存在。

最小点也可能不唯一。取 $\frac{1}{2}(uv-1)^2$，固定 $v=0$ 时，条件函数恒等于 $\frac{1}{2}$，每个 u 都是最小点。这时算法必须事先规定怎样选，常见的规则有“当前值已是最小点就不动”或“取离当前点最近的最小点”。没有这样的规则，迭代序列就没有确定的含义，第 12.7.3小节会看到，解的选择还影响收敛结论。

二次目标的块解 对二次目标，条件子问题有显式解。设

$$f(\boldsymbol{x})=\frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{Q}\boldsymbol{x}-\boldsymbol{b}^{\top}\boldsymbol{x},$$

其中 $\boldsymbol{Q}$ 对称，块 J 的主子矩阵 $\boldsymbol{Q}_{J,J}$ 正定，$\bar{J}$ 是 J 的补集。令偏梯度为零，

$$\boldsymbol{Q}_{J,J}\boldsymbol{x}_J+\boldsymbol{Q}_{J,\bar{J}}\boldsymbol{x}_{\bar{J}}-\boldsymbol{b}_J=\boldsymbol{0},$$

解出

$$\boldsymbol{x}_J^{+}=\boldsymbol{Q}_{J,J}^{-1}\big(\boldsymbol{b}_J-\boldsymbol{Q}_{J,\bar{J}}\boldsymbol{x}_{\bar{J}}\big). \tag{12.8}$$

在式 (12.3)中更新 x_1。固定 $x_2=4$，条件函数是

$$\varphi(z)=z^2+4z+16,$$

令导数 $2z+4=0$，得到

$$z=-2,\qquad \varphi(-2)=12.$$

条件子问题已经精确解出，x_1 在固定 $x_2=4$ 时不可能更好了。但点 $(-2,4)$ 不是原问题的解，它的目标值是 12，而 $f^\star=0$；它的梯度也不为零：

$$\nabla f(-2,4)=(0,\,6).$$

12.1 分块问题
12.2 块坐标下降（BCD）
12.2.1 精确块更新
12.2.2 循环块坐标下降（Cyclic BCD）
12.2.3 随机块坐标下降（RBCD）
12.2.4 贪心块坐标下降（Greedy BCD）
12.3 局部近似更新
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.8 本章小结

第一个分量为零，说明 x_1 这一块确实调好了；第二个分量不为零，说明 x_2 还没有。图 12.6把这两件事画在一起。

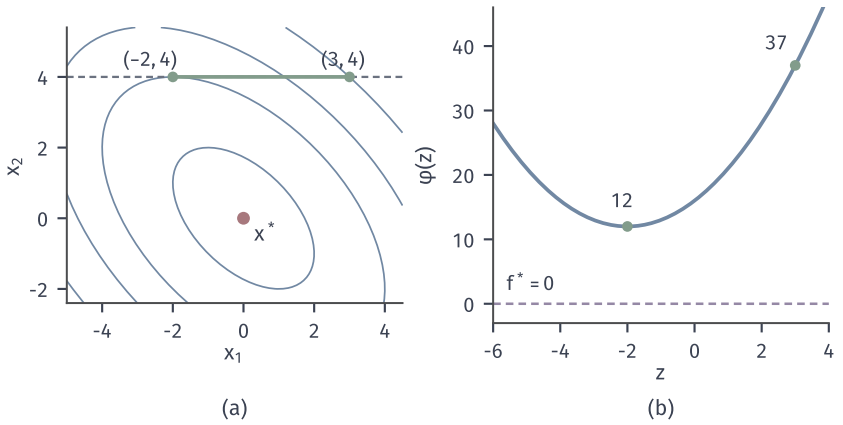


图 12.6 精确解条件子问题与解出整个问题的差别。(a) 固定 $x_2 = 4$（灰色虚线），在这条直线上从 $(3,4)$ 移到条件最小点 $(-2,4)$，该点处等高线与虚线相切，但离红色的最优解还远。(b) 沿虚线的条件函数 $\varphi(z) = z^2 + 4z + 16$，绿点的值从 37 降到 12；紫色虚线是完整问题的最优值 0。

12.2.2 循环块坐标下降（Cyclic BCD）

主要思想 最朴素的选块方式是按固定顺序轮流，这就是**循环块坐标下降**（cyclic block coordinate descent）。依次把 $J_1, \dots, J_B$ 各更新一次称为一**轮**（epoch）。后面的块读取的是本轮已经更新的新值，这一点很关键：刚得到的信息立刻被用上。

对二次目标，单坐标的循环更新就是线性方程组的 Gauss–Seidel 迭代，其收敛条件和误差传播的矩阵形式，可参考卷二第 14 章“定常迭代法”。这里我们关心的是耦合怎样决定速度。

把式 (12.3)中的交叉项系数换成参数 c，$|c| < 2$，考虑

$$f_c(\boldsymbol{x}) = x_1^2 + c x_1 x_2 + x_2^2. \tag{12.9}$$

令 $\partial_1 f_c = 2x_1 + c x_2 = 0$，$\partial_2 f_c = c x_1 + 2x_2 = 0$，得到两条更新规则

$$x_1 \leftarrow -\frac{c}{2} x_2, \qquad x_2 \leftarrow -\frac{c}{2} x_1. \tag{12.10}$$

第一步之后，$x_1 = -\frac{c}{2} x_2$ 总是成立，把它代入第二条规则，x_2 的新值是旧值的 $(c/2)^2$ 倍。所以从第二轮起，每一轮

$$x_2^{\text{new}} = \left(\frac{c}{2}\right)^2 x_2^{\text{old}}. \tag{12.11}$$

$c=0$ 时没有耦合，一轮就到最优解；c 越接近 2，等高线越扁越斜，收缩越慢。

变量

- $\boldsymbol{x}^{(t)}$：第 t 轮结束时的点，在原处逐块覆盖。
- $J_1,\dots,J_B$：固定的块顺序。例中 $B=2$，$J_1=\{1\}$，$J_2=\{2\}$。
- ε：完整梯度范数的容差。

初始化　选定可行的起点和块顺序，令 $t=0$。例中用式 (12.3)，$c=1$，容差 $\varepsilon=10^{-3}$，起点是

$$\boldsymbol{x}^{(0)}=(3,4),\qquad f(\boldsymbol{x}^{(0)})=37.$$

每轮更新　在第 t 轮中，对 $k=1,\dots,B$ 依次执行：

1. **读取新值**。固定其他块的最新取值，形成块 J_k 的条件子问题。
2. **精确求解**。按式 (12.6)更新块 J_k。例中第一轮由式 (12.10)，先用 $x_2=4$ 更新 x_1，再用新的 x_1 更新 x_2：

   $$x_1=-2,\qquad x_2=1.$$

   两次更新后的目标值依次是 12 和 3。

   例中第二轮读到 $x_2=1$，然后读到新的 x_1：

   $$x_1=-\tfrac{1}{2},\qquad x_2=\tfrac{1}{4}.$$

   目标值依次是 $\frac{3}{4}$ 和 $\frac{3}{16}$。

   例中第三轮得到

   $$x_1=-\tfrac{1}{8},\qquad x_2=\tfrac{1}{16},$$

   目标值依次是 $\frac{3}{64}$ 和 $\frac{3}{256}$。
3. **检查停止**。一轮结束后计算 $\|\nabla f(\boldsymbol{x}^{(t+1)})\|_2$，不超过 ε 就停止，否则令 $t\leftarrow t+1$。例中第 t 轮结束时

   $$\nabla f(\boldsymbol{x}^{(t)})=\big(-3\cdot 4^{1-t},\,0\big).$$

规律很清楚：第一步之后，每做一次坐标更新，目标值乘以 $\frac{1}{4}$。第 t 轮结束时

$$\boldsymbol{x}^{(t)} = \left(-2 \cdot 4^{1-t},\ 4^{1-t}\right), \qquad f(\boldsymbol{x}^{(t)}) = 3 \cdot 16^{1-t}.$$

梯度范数不超过 10^{-3} 要求 $3 \cdot 4^{1-t} \le 10^{-3}$，即 $t \ge 7$。最终得到

$$\boldsymbol{x}^{(7)} = \left(-4.88 \times 10^{-4},\ 2.44 \times 10^{-4}\right).$$

耦合与顺序的影响 图 12.7画出了两种耦合下的阶梯路径。(a) 中 $c = 1$，先更新 x_1 的路径向左上转折，先更新 x_2 的路径向右下转折：顺序改变路径，但两条路径都按因子 $\frac{1}{4}$ 收缩。(b) 中 $c = 1.8$，路径沿狭长的谷底爬行，每一阶都很短，每轮收缩因子变成 0.81。

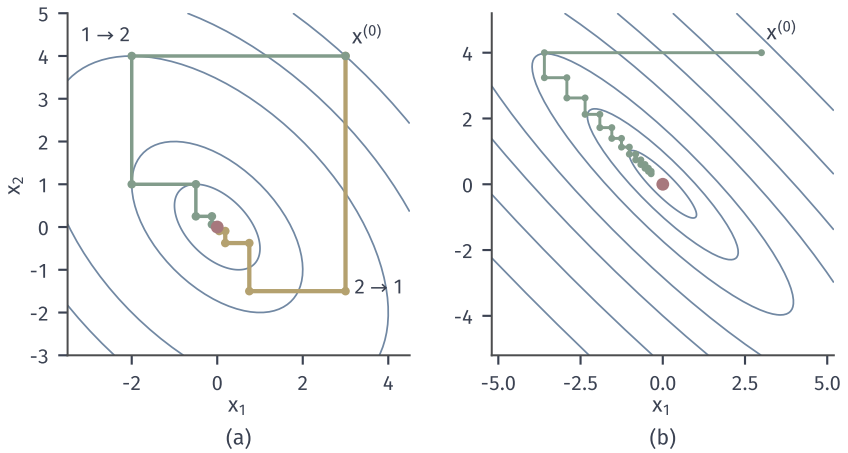


图 12.7 循环坐标下降的阶梯路径，从 $(3, 4)$ 出发。(a)$c = 1$，绿色先更新 x_1，黄色先更新 x_2，各画三轮，都按式 (12.11)的因子 $\frac{1}{4}$ 收缩。(b)$c = 1.8$，绿色路径画十二轮，变量耦合越强，每一阶越短。

阶梯形状的来源是：每次只能沿坐标轴走，而谷底方向是斜的。这好比在只能走东西、南北方向的棋盘式街道上，要朝东北方向下山，只能东一段、北一段地拼出来，而且每一段都不能走得太远，否则就偏离了谷底。变量的耦合就是这条斜谷的走向，耦合越强，能走的每一段越短。

固定循环与每轮打乱 二维时顺序只影响第一步，维数高了影响会大得多。实践中常在每轮开始时重新打乱顺序，这称为随机重排。它与固定循环的差别在于顺序每轮不同，与下一小节的独立随机选块的差别在于一轮内每块恰好出现一次。

后一个差别在分析中很要紧。一轮内已经选过的块不会再被选到，所以“这一步选到块 J 的概率”依赖于本轮前面选过什么，不再是与历史无关

12.1 分块问题
12.2 块坐标下降（BCD）
12.2.1 精确块更新
12.2.2 循环块坐标下降（Cyclic BCD）
12.2.3 随机块坐标下降（RBCD）
12.2.4 贪心块坐标下降（Greedy BCD）
12.3 局部近似更新
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.8 本章小结

的固定值。下一小节取条件期望的论证用不上，每轮打乱的收敛分析要另外处理。

图 12.8是一个数值实例。这个目标的各个变量两两等强度耦合，起点随机，固定循环明显慢于另外两种规则，每轮打乱和独立随机几乎一样。这只是一个具体问题上的观察，不是普遍定理；在另外的问题上，固定循环可以和随机规则一样快。

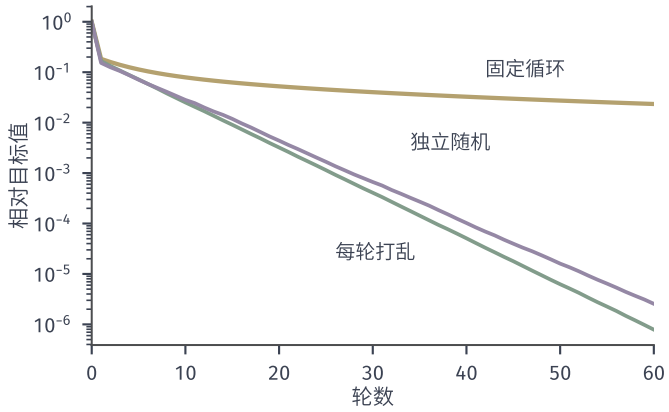


图 12.8　三种更新顺序在同一目标上的比较。目标为 $\frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{Q}\boldsymbol{x}$，$\boldsymbol{Q}=0.1\,\boldsymbol{I}+0.9\,\mathbf{1}\mathbf{1}^{\top}$，$n=30$，单坐标精确更新，纵轴为目标值与起点目标值之比。黄线是固定循环，绿线是每轮打乱，紫线是独立随机（每轮 n 次更新），后两者是 30 次重复的几何平均。

12.2.3 随机块坐标下降（RBCD）

主要思想　循环规则的路径取决于顺序，分析也依赖整轮的累积效应。如果每步独立地抽一块，就可以用平均值来分析单步进展，这是**随机块坐标下降**（randomized block coordinate descent，RBCD）的出发点。

设第 t 步与历史独立地以固定概率 $p_J>0$ 抽取块 J，$\sum_J p_J=1$。记块 J 精确更新带来的真实下降量为 $\Delta_J(\boldsymbol{x})=f(\boldsymbol{x})-f(\boldsymbol{x}^{+J})$，其中 $\boldsymbol{x}^{+J}$ 是只更新块 J 得到的点。已知当前点 $\boldsymbol{x}^{(t)}$ 时，新点的目标值是随机的，它的条件期望是各种可能结果的加权平均：

$$\mathbb{E}\big[f(\boldsymbol{x}^{(t+1)})\mid \boldsymbol{x}^{(t)}\big]=f(\boldsymbol{x}^{(t)})-\sum_{J}p_J\,\Delta_J(\boldsymbol{x}^{(t)}). \tag{12.12}$$

这里只用到离散情形的加权平均，条件期望的一般定义可参考卷七第 4 章“条件期望与条件分布”。

式 (12.12)说明，随机规则的平均进展就是各块进展的加权平均，所以只要每块都有保底的进展，平均也有。

单步平均的计算 对单坐标精确更新的二次目标，真实下降量可以写出来。条件函数是开口系数为 $Q_{j,j}/2$ 的抛物线，当前斜率是 $\partial_j f$，最小化后下降

$$\Delta_j(\boldsymbol{x}) = \frac{(\partial_j f(\boldsymbol{x}))^2}{2Q_{j,j}}. \tag{12.13}$$

在起点 $(3,4)$，偏导数和两个下降量是

$$\partial_1 f = 10, \qquad \partial_2 f = 11, \qquad \Delta_1 = 25, \qquad \Delta_2 = \frac{121}{4} = 30.25.$$

均匀抽取时，平均下降量是

$$\frac{1}{2}(25 + 30.25) = 27.625,$$

平均目标值是 $37 - 27.625 = 9.375$。图 12.9把两个可能的结果和平均值放在一起。

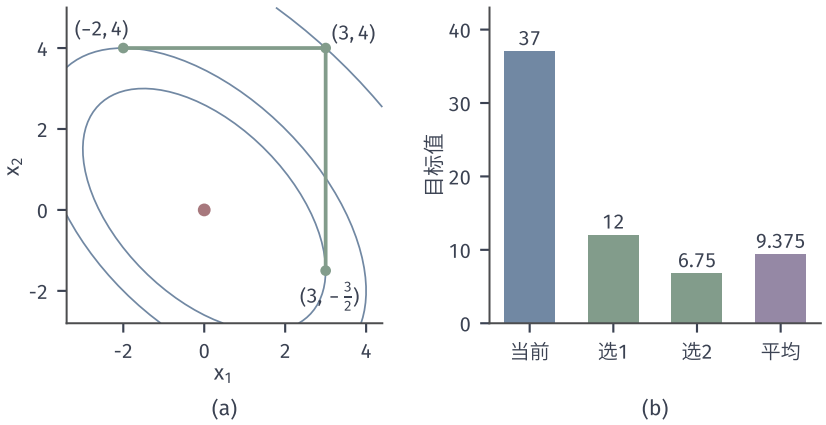


图 12.9 随机选块的一步。(a) 从 $(3,4)$ 出发，抽到 x_1 走到 $(-2,4)$，抽到 x_2 走到 $(3,-\frac{3}{2})$，蓝色是过这三点的等高线。(b) 当前目标值、两种结果的目标值，以及均匀抽取时目标值的条件期望 9.375（紫色）。

计算过程 RBCD 的计算过程与循环规则只差选块一步。例中取一个抽样结果，依次抽到块 $2,1,1,2$，从 $(3,4)$ 出发的四次更新是：

$$\begin{aligned}
&\text{抽到 } 2: \quad \boldsymbol{x} = (3, -\tfrac{3}{2}), \quad f = 6.75,\\
&\text{抽到 } 1: \quad \boldsymbol{x} = (\tfrac{3}{4}, -\tfrac{3}{2}), \quad f = 1.6875,\\
&\text{抽到 } 1: \quad \boldsymbol{x} = (\tfrac{3}{4}, -\tfrac{3}{2}), \quad f = 1.6875,\\
&\text{抽到 } 2: \quad \boldsymbol{x} = (\tfrac{3}{4}, -\tfrac{3}{8}), \quad f = 0.421875.
\end{aligned}$$

12.1 分块问题
12.2 块坐标下降（BCD）
12.2.1 精确块更新
12.2.2 循环块坐标下降（Cyclic BCD）
12.2.3 随机块坐标下降（RBCD）
12.2.4 贪心块坐标下降（Greedy BCD）
12.3 局部近似更新
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.8 本章小结

第三次抽到的块与上一次相同，由于上一次已经把这一块解到最优，这次更新什么也没有改变。精确块更新时连续抽到同一块就是白费，这是独立随机选块的一项代价。

非均匀抽取 概率不一定要相等。比较两种选择：均匀抽取 $p_j = 1/n$，以及按曲率抽取 $p_j = Q_{j,j}/\operatorname{tr} \boldsymbol{Q}$。后一种由式 (12.13)给出一个不依赖下标的平均下降：

$$\sum_j p_j \Delta_j = \frac{\|\nabla f(\boldsymbol{x})\|_2^2}{2 \operatorname{tr} \boldsymbol{Q}}. \tag{12.14}$$

哪种更好取决于偏导数的分布。设 $Q_{1,1} = 1$，$Q_{2,2} = 25$，则 $p = (\frac{1}{26}, \frac{25}{26})$。若偏导数是 $(1, 25)$，下降量是 $(0.5, 12.5)$，两种规则的平均下降量分别是 6.5 和约 12.04，按曲率抽取更好。

若偏导数是 $(3, 5)$，下降量是 $(4.5, 0.5)$，两种规则的平均下降量分别是 2.5 和约 0.65，按曲率抽取反而更差。所以非均匀抽取不是免费的改进，它把访问次数押在某些块上，收益要看目标的结构。

不能照搬逆概率校正 “按概率抽取”很容易让人想起另一种做法：把抽到的量除以被抽中的概率，使它的期望等于要估计的量。这样做的目的是构造全梯度的无偏估计。但这里并没有估计什么：抽到块 J 时读到的偏梯度是准确的，抽样决定的只是更新哪里。

如果仍然把步长放大 $1/(Bp_J)$ 倍，步子就会过长。例中取 $p_1 = \frac{1}{4}$，放大倍数是 $1/(2 \cdot \frac{1}{4}) = 2$，而精确更新的位移本来是 -5，放大后 x_1 变成

$$x_1 = 3 - 2 \times 5 = -7.$$

新的目标值是

$$f(-7, 4) = 49 - 28 + 16 = 37,$$

恰好越过最小点到了抛物线的另一侧，一点进展也没有。放大倍数再大，目标值就上升了。

因此，RBCD 的速率不能从样本估计的结论推出，需要结合块内怎样求解、各块被访问的概率以及目标的结构建立。第 12.7.3小节在块内用梯度步、概率均匀的情形下给出完整的证明。

12.2.4 贪心块坐标下降（Greedy BCD）

主要思想 既然各块进展不同，为什么不直接挑进展最大的一块？这就是**贪心块坐标下降**（greedy block coordinate descent）。最直接的做法是对每一块都解一遍条件子问题，比较真实下降量 Δ_J，再选最大的。可是这等于做了 B 次块更新，只用其中一次，太浪费了。

实用的贪心规则用便宜的指标代替真实下降量。偏梯度描述当前块的陡峭程度，最简单的指标就是偏梯度的范数：

$$J^{(t)} \in \arg\max_{J} \|\nabla_J f(\boldsymbol{x}^{(t)})\|_2. \tag{12.15}$$

这称为Gauss–Southwell 规则（Gauss–Southwell rule）。在起点 $(3,4)$，偏导数是 $(10,11)$，规则选 x_2，而 $\Delta_2 = 30.25 > \Delta_1 = 25$，确实选中了进展更大的一块。

块光滑常数与带曲率的指标　偏梯度大不等于下降多：块的曲率高时，能走的距离短。要把曲率算进去，先要量化“沿一块移动时梯度变化多快”。

> **定义 12.3　块光滑常数**　设 $f:\mathbb{R}^n\to\mathbb{R}$ 可微。若存在 $L_J>0$，使对一切 $\boldsymbol{x}\in\mathbb{R}^n$ 和 $\boldsymbol{h}\in\mathbb{R}^{|J|}$，
>
> $$\|\nabla_J f(\boldsymbol{x}+\boldsymbol{U}_J\boldsymbol{h})-\nabla_J f(\boldsymbol{x})\|_2 \le L_J\|\boldsymbol{h}\|_2, \tag{12.16}$$
>
> 则称 f 关于块 J 是 L_J 光滑的，L_J 称为**块光滑常数**（block smoothness constant）。

固定其他块后，函数 $\boldsymbol{h}\mapsto f(\boldsymbol{x}+\boldsymbol{U}_J\boldsymbol{h})$ 的梯度正是 $\nabla_J f(\boldsymbol{x}+\boldsymbol{U}_J\boldsymbol{h})$，式 (12.16)说它的光滑常数是 L_J。对这个函数用第 5章的下降引理，得到沿块 J 的二次上界：

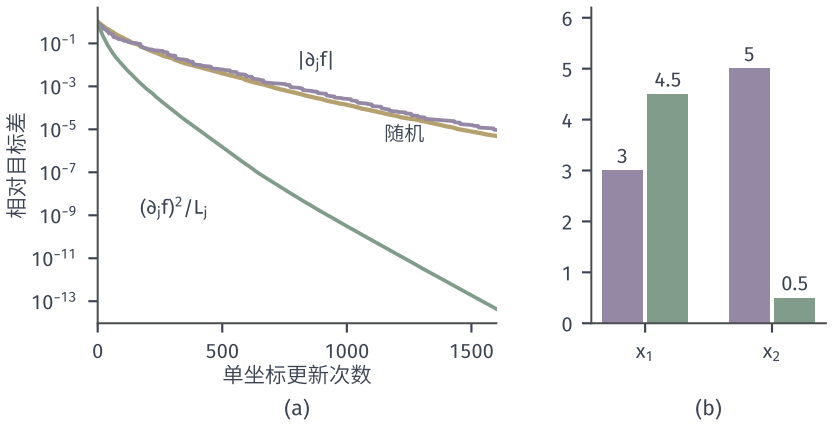
$$f(\boldsymbol{x}+\boldsymbol{U}_J\boldsymbol{h}) \le f(\boldsymbol{x}) + \langle \nabla_J f(\boldsymbol{x}), \boldsymbol{h}\rangle + \frac{L_J}{2}\|\boldsymbol{h}\|_2^2. \tag{12.17}$$

右边在 $\boldsymbol{h}=-\nabla_J f(\boldsymbol{x})/L_J$ 处取最小，代入得到一个保底的下降量：

$$f(\boldsymbol{x}) - f\Big(\boldsymbol{x}-\frac{1}{L_J}\boldsymbol{U}_J\nabla_J f(\boldsymbol{x})\Big) \ge \frac{\|\nabla_J f(\boldsymbol{x})\|_2^2}{2L_J}. \tag{12.18}$$

于是一个更合理的指标是这个保底下降量本身，即选使 $\|\nabla_J f\|_2^2/L_J$ 最大的块。

举一个二者选择不同的例子。设两个坐标的偏导数是 $(3,5)$，块光滑常数是 $(1,25)$。按偏导数大小选 x_2，保底下降量是 $25/50=0.5$；按 $\|\nabla_J f\|_2^2/L_J$ 选 x_1，保底下降量是 $9/2=4.5$。



12.1 分块问题
12.2 块坐标下降（BCD）
12.3 局部近似更新
12.3.1 块坐标梯度下降（BCGD）
12.3.2 加速邻近坐标梯度（APCG）
12.3.3 块坐标 Newton 法
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.8 本章小结

图 12.10　选块指标的比较。(a)$N=80$、$n=40$ 的最小二乘，各列尺度相差很大，单坐标精确更新，纵轴为目标差与初值之比。黄线是均匀随机（10 次重复的几何平均），紫线按 $|\partial_j f|$ 选坐标，绿线按 $(\partial_j f)^2/L_j$ 选坐标。(b) 文中手算例子的两个坐标：紫色柱是 $|\partial_j f|$，绿色柱是保底下降量 $(\partial_j f)^2/(2L_j)$。

图 12.10(a) 显示，当各列尺度差别很大时，只看偏梯度大小的规则并不比随机规则好，把曲率算进去之后才快了很多。(b) 是手算的例子：两个指标选中了不同的坐标，而绿色柱才是能保证的下降量。

贪心指标的代价　贪心规则需要知道所有块的偏梯度。若每次更新后要重算全部偏梯度，一步的代价就和一次全梯度相同，这时贪心规则很难划算。

当目标的耦合稀疏时，更新一块只影响少数几块的偏梯度，可以增量维护，并用优先队列取最大值，贪心规则才真正便宜。

复合目标的指标　目标含非光滑项时，只看偏梯度会选错块。设 $F=f+g$，$g(\boldsymbol{x})=\sum_J g_J(\boldsymbol{x}_J)$ 是按块可分的凸函数，块 J 的二次上界加上 g_J 就成了局部模型。把模型能带来的下降量当作指标：

$$\Delta_J^g(\boldsymbol{x})=-\min_{\boldsymbol{h}}\Big\{\langle\nabla_J f(\boldsymbol{x}),\boldsymbol{h}\rangle+\frac{L_J}{2}\|\boldsymbol{h}\|_2^2 + g_J(\boldsymbol{x}_J+\boldsymbol{h})-g_J(\boldsymbol{x}_J)\Big\}. \tag{12.19}$$

取 $g_J=|\cdot|$，当前 $x_j=0$，$L_j=1$。若偏导数是 0.5，$h=0$ 是最小点，指标为 0，这个坐标不会动，尽管偏导数不为零。若偏导数是 2，模型最小点是 $h=-1$，指标为 0.5，这一块才有进展可言。

12.3 局部近似更新

精确块更新要求条件子问题便宜可解。许多目标不满足这一点，比如条件函数含对数或指数，每解一次都要内层迭代。这就需要回答：解不动条件

12.1 分块问题
12.2 块坐标下降（BCD）
12.3 局部近似更新
12.3.1 块坐标梯度下降（BCGD）
12.3.2 加速邻近坐标梯度（APCG）
12.3.3 块坐标 Newton 法
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.8 本章小结

子问题时，怎样在当前块上构造一个可以计算的局部模型，并用它推进完整目标？

三种模型对应三种读数。下表把它们和精确块更新放在一起比较。

更新	每步读取	子问题	接受条件
精确块解	条件函数	条件子问题	无需检验
BCGD	当前点偏梯度	闭式的二次函数	步长 $1/L_J$
APCG	外推点偏梯度	闭式或邻近映射	无单调保证
块 Newton	偏梯度与块 Hessian	块内线性方程	线搜索等

下面逐个看它们要解什么子问题、需要什么接受条件。

12.3.1 块坐标梯度下降（BCGD）

主要思想 上一节的上界 (12.17)是块 J 上的一个二次模型，它在当前点与 f 相等，并且处处不低于 f。最小化这个上界代替最小化 f，只走一步块梯度：

$$\boldsymbol{x}_J^{(t+1)} = \boldsymbol{x}_J^{(t)} - \frac{1}{L_J}\nabla_J f(\boldsymbol{x}^{(t)}), \qquad \boldsymbol{x}_i^{(t+1)} = \boldsymbol{x}_i^{(t)} \ (i \notin J). \tag{12.20}$$

这就是**块坐标梯度下降**（block coordinate gradient descent，BCGD）。由式 (12.18)，每一步完整目标至少下降

$$f(\boldsymbol{x}^{(t)}) - f(\boldsymbol{x}^{(t+1)}) \geq \frac{\|\nabla_J f(\boldsymbol{x}^{(t)})\|_2^2}{2L_J}. \tag{12.21}$$

图 12.11(a) 是一个不能闭式解出的条件函数 $\varphi(z) = \sqrt{1+z^2} - z/2$，它的二阶导数不超过 1，所以 $L_J = 1$。当前点 $z = 2$ 处 $\varphi'(2) \approx 0.394$，上界的最小点是 $z^+ = 2 - 0.394 = 1.606$。上界（绿）紧贴在 φ（蓝）的上方，上界的最小值高于真实函数在 z^+ 处的值，所以真实下降量不会少于上界的下降量。

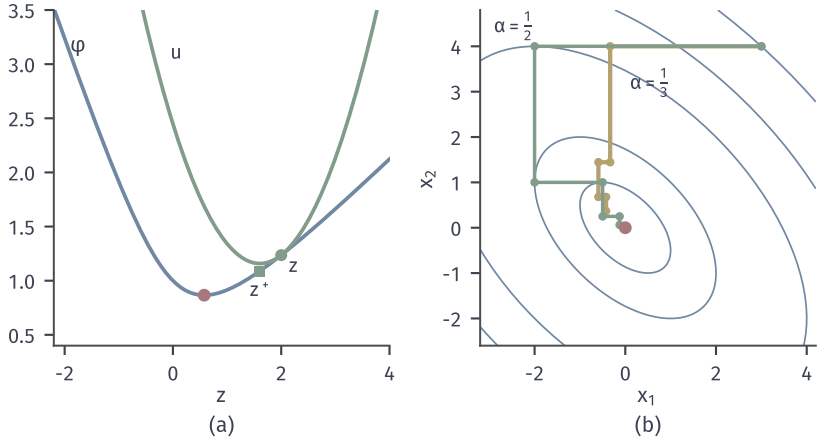


图 12.11　块梯度步的两个视角。(a) 条件函数 $\varphi(z)=\sqrt{1+z^2}-z/2$（蓝）与 $L_J=1$ 的二次上界（绿），绿点是当前点 $z=2$，空心点和方块分别是上界和原函数在上界最小点 $z^+\approx 1.606$ 处的值，红点是原函数的最小点 $z\approx 0.577$。(b) 式 (12.3)上循环 BCGD 的路径，绿色是块步长 $\alpha=1/L_j=\frac{1}{2}$，黄色是全局步长 $\alpha=1/L=\frac{1}{3}$，各画三轮。

块常数与全局常数　最小二乘按样本数归一化时，目标是

$$f(\boldsymbol{x})=\frac{1}{2N}\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|_2^2.$$

坐标 j 的偏导数和块光滑常数是

$$\partial_j f(\boldsymbol{x})=\frac{1}{N}\boldsymbol{a}_j^{\top}\boldsymbol{r},\qquad L_j=\frac{\|\boldsymbol{a}_j\|_2^2}{N},\tag{12.22}$$

其中 $\boldsymbol{r}=\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}$ 是残差。若目标不除以 N，L_j 和偏导数中的 $1/N$ 同时去掉，步长与偏导数的乘积不变，所以两种写法走出的路径相同。块 J 含多列时，$L_J=\lambda_{\max}(\boldsymbol{A}_J^{\top}\boldsymbol{A}_J)/N$，其中 $\boldsymbol{A}_J$ 是由这些列组成的子矩阵。

全局光滑常数是 $L=\lambda_{\max}(\boldsymbol{A}^{\top}\boldsymbol{A})/N$。设 $\boldsymbol{H}=\boldsymbol{A}^{\top}\boldsymbol{A}/N$ 半正定，每个对角元 $L_j=\boldsymbol{e}_j^{\top}\boldsymbol{H}\boldsymbol{e}_j$ 不超过最大特征值，而最大特征值又不超过所有特征值之和，即迹。因此

$$L_j\le L\le\sum_{i=1}^{n}L_i.\tag{12.23}$$

式 (12.23)的左半边解释了坐标法为什么敢走得更远：上界只要在这一个方向上成立，曲率只需按这一方向计算，而全局步长必须照顾最陡的方向。列相关性很强时 L 可接近 $\sum_i L_i$，坐标步长可以比全局步长大 n 倍。

例中 $\boldsymbol{A}$ 的两列平方范数都是 2，未归一化时

$$L_1=L_2=2,\qquad L=\lambda_{\max}(\boldsymbol{Q})=3.$$

块步长是 $\frac{1}{2}$，全局步长是 $\frac{1}{3}$。图 12.11(b) 比较了这两种步长：步长 $\frac{1}{3}$ 的每一阶都没有走到条件最小点，路径的收缩更慢。

变量

- $\boldsymbol{x} \in \mathbb{R}^n$：当前点。
- $\boldsymbol{r} = \boldsymbol{A}\boldsymbol{x} - \boldsymbol{b} \in \mathbb{R}^N$：维护的残差，读偏导数时使用。
- L_j：各坐标的块光滑常数，事先算好。

初始化 算出各 L_j 和初始残差 $\boldsymbol{r}^{(0)}$，令 $t = 0$。例中用 $\boldsymbol{A}$ 的三行，$\boldsymbol{b} = \boldsymbol{0}$，$\boldsymbol{x}^{(0)} = (3, 4)$，不除以 N：

$$L_1 = L_2 = 2, \qquad \boldsymbol{r}^{(0)} = \boldsymbol{A}\boldsymbol{x}^{(0)} = (7, 3, 4).$$

每轮更新 按某个选块规则取坐标 j，然后：

1. **读偏导数**。计算 $\partial_j f = \boldsymbol{a}_j^{\top}\boldsymbol{r}$。例中第一轮先取 $j = 1$，

$$\partial_1 f = 7 + 3 = 10.$$

2. **更新变量**。由式 (12.20)，位移是 $\delta = -\partial_j f / L_j$，令 $x_j \leftarrow x_j + \delta$。例中

$$\delta = -5, \qquad x_1 = -2.$$

3. **更新残差**。令 $\boldsymbol{r} \leftarrow \boldsymbol{r} + \delta \boldsymbol{a}_j$，不重算矩阵乘向量。例中

$$\boldsymbol{r} = (7, 3, 4) - 5(1, 1, 0) = (2, -2, 4).$$

例中第一轮再取 $j = 2$，$\partial_2 f = 2 + 4 = 6$，$\delta = -3$，于是

$$x_2 = 1, \qquad \boldsymbol{r} = (2, -2, 4) - 3(1, 0, 1) = (-1, -2, 1).$$

此时目标值是 $\frac{1}{2}\|\boldsymbol{r}\|_2^2 = 3$。

例中第二轮取 $j = 1$，$\partial_1 f = -3$，$\delta = \frac{3}{2}$，于是

$$x_1 = -\tfrac{1}{2}, \qquad \boldsymbol{r} = \left(\tfrac{1}{2}, -\tfrac{1}{2}, 1\right).$$

再取 $j = 2$，$\partial_2 f = \frac{3}{2}$，$\delta = -\frac{3}{4}$，于是

$$x_2 = \tfrac{1}{4}, \qquad \boldsymbol{r} = \left(-\tfrac{1}{4}, -\tfrac{1}{2}, \tfrac{1}{4}\right).$$

12.1 分块问题
12.2 块坐标下降（BCD）
12.3 局部近似更新
12.3.1 块坐标梯度下降（BCGD）
12.3.2 加速邻近坐标梯度（APCG）
12.3.3 块坐标 Newton 法
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.8 本章小结

此时目标值是 $\frac{3}{16}$。

迭代结束的条件与第 12.2.2小节相同。最终得到的点和循环精确更新完全一致，第 t 轮结束时都是 $\boldsymbol{x}^{(t)} = (-2\cdot 4^{1-t}, 4^{1-t})$。原因是二次目标的条件函数本身就是抛物线，上界 (12.17)取 $L_j = Q_{j,j}$ 时恰好等于条件函数，上界的最小点就是条件最小点。对一般光滑目标，两种更新不同。

12.3.2 加速邻近坐标梯度（APCG）

要解决的问题 BCGD 每步只用当前点的信息，和梯度下降一样没有利用走过的路。第 6章的加速方法靠外推把凸目标的目标差从 $O(1/t)$ 提到 $O(1/t^2)$，自然想把同样的思想用在坐标更新上。**加速邻近坐标梯度**（accelerated proximal coordinate gradient，APCG）方法就做这件事，并且允许目标含按块可分的非光滑项。

考虑

$$\min_{\boldsymbol{x}\in\mathbb{R}^n} F(\boldsymbol{x}) = f(\boldsymbol{x}) + \sum_J g_J(\boldsymbol{x}_J), \tag{12.24}$$

其中 f 是凸函数，关于每一块满足定义 12.3，每个 g_J 是适当、闭的凸函数。回顾第 11章的邻近映射

$$\operatorname{prox}_{\alpha g}(\boldsymbol{v}) = \arg\min_{\boldsymbol{u}}\left\{g(\boldsymbol{u}) + \frac{1}{2\alpha}\|\boldsymbol{u}-\boldsymbol{v}\|_2^2\right\},$$

它把“沿梯度走一步”之后的点拉回到非光滑项喜欢的位置，$g\equiv 0$ 时就是恒等映射。

三条序列 APCG 维护三条序列，图 12.12是它们的关系。$\boldsymbol{x}^{(t)}$ 是报告给用户的点；$\boldsymbol{z}^{(t)}$ 记录累积的梯度信息，每次走较长的步子；$\boldsymbol{y}^{(t)}$ 是这两者的组合，只在这一点上读偏梯度。

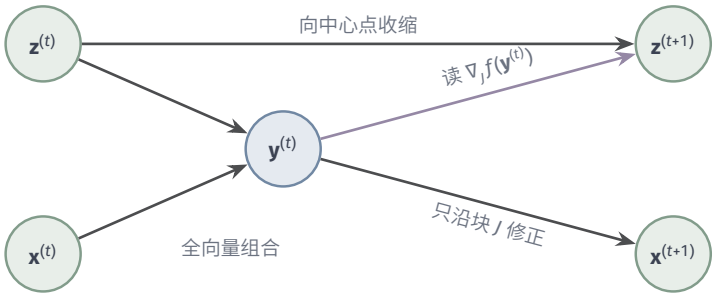


图 12.12 APCG 一步中三条序列的依赖关系。$\boldsymbol{y}^{(t)}$ 是 $\boldsymbol{x}^{(t)}$ 与 $\boldsymbol{z}^{(t)}$ 的组合，这一步通常改变全部分量；在 $\boldsymbol{y}^{(t)}$ 处读抽中块 J 的偏梯度（紫色）后，$\boldsymbol{z}$ 沿块 J 走一长步，$\boldsymbol{x}^{(t+1)}$ 只在 $\boldsymbol{y}^{(t)}$ 的块 J 上修正一步。

为什么 $\boldsymbol{z}$ 的步长要放大？一次只抽一块，每一块平均 B 步才轮到一次。$\boldsymbol{z}$ 是积累全局信息的序列，它要把偶尔读到的这一块的信息放大，才能代表整个梯度的作用，所以步长是 $1/L_J$ 的 $1/(B\alpha^{(t)})$ 倍。$\boldsymbol{x}$ 只负责走稳妥的短步。这和第 6章的外推相似：先在外推点读梯度，再决定位移。不同的是，这里的读数只有一块，$\boldsymbol{z}$ 的放大倍数正是用来补偿这一点的。

分析中用到按块常数加权的范数

$$\|\boldsymbol{x}\|_L^2 = \sum_J L_J \|\boldsymbol{x}_J\|_2^2. \tag{12.25}$$

设 f 关于这个范数有强凸常数 $\mu_L \ge 0$，也就是说，对任意 $\boldsymbol{x}, \boldsymbol{y}$，

$$f(\boldsymbol{y}) \ge f(\boldsymbol{x}) + \langle \nabla f(\boldsymbol{x}), \boldsymbol{y}-\boldsymbol{x}\rangle + \frac{\mu_L}{2}\|\boldsymbol{y}-\boldsymbol{x}\|_L^2.$$

$\mu_L = 0$ 表示只要求凸。这样定义的 μ_L 不超过 1，因为沿块方向它受块光滑常数限制。

迭代公式 记 B 为块数，选 $\gamma^{(0)} \in [\mu_L, 1]$ 且 $\gamma^{(0)} > 0$，令 $\boldsymbol{z}^{(0)} = \boldsymbol{x}^{(0)}$。第 t 步先由下面的方程取 $\alpha^{(t)} \in (0, 1/B]$，并更新另外两个参数：

$$\begin{aligned} B^2(\alpha^{(t)})^2 &= (1-\alpha^{(t)})\gamma^{(t)} + \alpha^{(t)}\mu_L, \\ \gamma^{(t+1)} &= B^2(\alpha^{(t)})^2, \qquad \beta^{(t)} = \frac{\alpha^{(t)}\mu_L}{\gamma^{(t+1)}}. \end{aligned} \tag{12.26}$$

然后构造外推点和 $\boldsymbol{z}$ 的中心点：

$$\begin{aligned} \boldsymbol{y}^{(t)} &= \frac{\alpha^{(t)}\gamma^{(t)}\boldsymbol{z}^{(t)} + \gamma^{(t+1)}\boldsymbol{x}^{(t)}}{\alpha^{(t)}\gamma^{(t)} + \gamma^{(t+1)}}, \\ \boldsymbol{w}^{(t)} &= (1-\beta^{(t)})\boldsymbol{z}^{(t)} + \beta^{(t)}\boldsymbol{y}^{(t)}. \end{aligned} \tag{12.27}$$

独立均匀地抽一块 J，在 $\boldsymbol{y}^{(t)}$ 处读偏梯度。记 $\tau = 1/(B\alpha^{(t)}L_J)$，这是比 $1/L_J$ 更长的步长。块 J 上用邻近步更新 $\boldsymbol{z}$，其余块取中心点的值：

$$\boldsymbol{z}_J^{(t+1)} = \operatorname{prox}_{\tau g_J}\big(\boldsymbol{w}_J^{(t)} - \tau \nabla_J f(\boldsymbol{y}^{(t)})\big), \qquad \boldsymbol{z}_i^{(t+1)} = \boldsymbol{w}_i^{(t)} \ (i \notin J). \tag{12.28}$$

最后由 $\boldsymbol{y}$ 和 $\boldsymbol{z}$ 的变化得到新迭代点：

$$\boldsymbol{x}^{(t+1)} = \boldsymbol{y}^{(t)} + B\alpha^{(t)}\big(\boldsymbol{z}^{(t+1)} - \boldsymbol{w}^{(t)}\big). \tag{12.29}$$

式 (12.28)中 $\boldsymbol{z}^{(t+1)}$ 和 $\boldsymbol{w}^{(t)}$ 只在块 J 上不同，所以 $\boldsymbol{x}^{(t+1)}$ 相对 $\boldsymbol{y}^{(t)}$ 也只改变块 J。$g_J \equiv 0$ 时，代入式 (12.29)，块 J 上得到

$$\boldsymbol{x}_J^{(t+1)} = \boldsymbol{y}_J^{(t)} - \frac{1}{L_J}\nabla_J f(\boldsymbol{y}^{(t)}),$$

这正是在外推点上的一步 BCGD。外推本身却可能改变全向量，这是加速方法计算上的主要负担，下文计入成本。

变量

- $\boldsymbol{x}^{(t)}, \boldsymbol{z}^{(t)} \in \mathbb{R}^n$：报告点和累积序列。
- $\boldsymbol{y}^{(t)}, \boldsymbol{w}^{(t)} \in \mathbb{R}^n$：外推点和 $\boldsymbol{z}$ 的中心点，每步由前两者算出。
- $\alpha^{(t)}, \beta^{(t)}, \gamma^{(t)}$：由式 (12.26)确定的标量。

初始化 令 $\boldsymbol{z}^{(0)} = \boldsymbol{x}^{(0)}$，选 $\gamma^{(0)}$。取 $\gamma^{(0)} = \mu_L > 0$ 时，由式 (12.26)可知各参数不随 t 变化：

$$\gamma^{(t)} = \mu_L, \qquad \alpha^{(t)} = \beta^{(t)} = \frac{\sqrt{\mu_L}}{B}.$$

例中为了得到整齐的参数，把交叉项系数改成 $c = \frac{3}{2}$，即用 $f_{3/2}$，$B = 2$。此时 $L_1 = L_2 = 2$，$\|\boldsymbol{x}\|_L^2 = 2\|\boldsymbol{x}\|_2^2$，Hessian 的最小特征值是 $\frac{1}{2}$，于是

$$\mu_L = \frac{1}{4}, \qquad \alpha^{(t)} = \beta^{(t)} = \frac{1}{4}.$$

起点仍取 $\boldsymbol{x}^{(0)} = \boldsymbol{z}^{(0)} = (3, 4)$，目标值 $f = 43$。$g_J \equiv 0$，步长 $\tau = 1/(2 \cdot \frac{1}{4} \cdot 2) = 1$。

每轮更新 第 t 步依次做：

1. **外推**。按式 (12.27)算 $\boldsymbol{y}^{(t)}$ 和 $\boldsymbol{w}^{(t)}$。例中公式化为

$$\boldsymbol{y} = \frac{4\boldsymbol{x} + \boldsymbol{z}}{5}, \qquad \boldsymbol{w} = \frac{3}{4}\boldsymbol{z} + \frac{1}{4}\boldsymbol{y}.$$

   第一步 $\boldsymbol{x} = \boldsymbol{z}$，所以 $\boldsymbol{y} = \boldsymbol{w} = (3, 4)$。

2. **抽块并读偏梯度**。例中第一步设抽到块 1，

$$\partial_1 f(\boldsymbol{y}) = 2 \cdot 3 + \tfrac{3}{2} \cdot 4 = 12.$$

3. **更新 $\boldsymbol{z}$**。按式 (12.28)。例中 $\tau = 1$，块 J 上 $\boldsymbol{z}_J^{+} = \boldsymbol{w}_J - \nabla_J f(\boldsymbol{y})$，第一步

$$\boldsymbol{z}^{(1)} = (-9, 4).$$

4. **更新 $\boldsymbol{x}$**。按式 (12.29)。例中块 J 上 $\boldsymbol{x}_J^{+} = \boldsymbol{y}_J - \frac{1}{2}\nabla_J f(\boldsymbol{y})$，第一步

$$\boldsymbol{x}^{(1)} = (-3, 4), \qquad f(\boldsymbol{x}^{(1)}) = 7.$$

例中第二步设抽到块 2。先算外推点和中心点，

$$\boldsymbol{y} = (-4.2,\ 4), \qquad \boldsymbol{w} = (-7.8,\ 4).$$

偏导数 $\partial_2 f(\boldsymbol{y}) = \frac{3}{2}(-4.2) + 8 = 1.7$，于是

$$\boldsymbol{z}^{(2)} = (-7.8,\ 2.3), \qquad \boldsymbol{x}^{(2)} = (-4.2,\ 3.15), \qquad f(\boldsymbol{x}^{(2)}) = 7.7175.$$

例中第三步设抽到块 1，同样计算得

$$\boldsymbol{y} = (-4.92,\ 2.98), \qquad \boldsymbol{w} = (-7.08,\ 2.47), \qquad \partial_1 f(\boldsymbol{y}) = -5.37,$$

于是

$$\boldsymbol{z}^{(3)} = (-1.71,\ 2.47), \qquad \boldsymbol{x}^{(3)} = (-2.235,\ 2.98), \qquad f(\boldsymbol{x}^{(3)}) = 3.885175.$$

第二步的目标值从 7 升到了 7.7175，这不是计算错误。APCG 在外推点上读偏梯度，$\boldsymbol{x}^{(t+1)}$ 相对 $\boldsymbol{y}^{(t)}$ 有下降保证，相对 $\boldsymbol{x}^{(t)}$ 却没有，目标值不是单调的。迭代持续到外部设定的更新次数或目标差估计达到要求为止，图 12.13(b) 是继续迭代的结果。

收敛结论 下面的结论把成立所需的条件都列了出来。证明要构造随机的估计序列，并逐步跟踪参数 $\alpha^{(t)}, \gamma^{(t)}$ 的递推，篇幅较长，读者可查阅 Lin、Lu 和 Xiao 关于 APCG 方法的原始论文。

定理 12.4　APCG 的收敛率 设问题 (12.24)的解集非空，f 是凸函数，满足定义 12.3（全空间上成立），且关于范数 (12.25)的强凸常数为 $\mu_L \geq 0$；每个 g_J 是适当、闭的凸函数，邻近子问题 (12.28)精确求解。设每步独立均匀地抽块，参数按式 (12.26)取，$\gamma^{(0)} \in [\mu_L, 1]$，$\gamma^{(0)} > 0$。记 $R_0 = \min \|\boldsymbol{x}^{(0)} - \boldsymbol{x}^\star\|_L$，最小值取遍所有最优解。则对一切 $t \geq 0$，

$$\mathbb{E}\big[F(\boldsymbol{x}^{(t)})\big] - F^\star \leq \min\left\{\left(1 - \frac{\sqrt{\mu_L}}{B}\right)^t,\ \left(\frac{2B}{2B + t\sqrt{\gamma^{(0)}}}\right)^2\right\} E_0, \tag{12.30}$$

其中

$$E_0 = F(\boldsymbol{x}^{(0)}) - F^\star + \frac{\gamma^{(0)}}{2} R_0^2. \tag{12.31}$$

这个结论有三层含义。$\mu_L = 0$ 时，第二项给出 $O(B^2/t^2)$ 的期望目标差，t 次更新相当于 t/B 轮，所以按轮数算是 $O(1/(t/B)^2)$，这是加速率。$\mu_L > 0$ 且取 $\gamma^{(0)} = \mu_L$ 时，第一项给出线性率，因子是 $1 - \sqrt{\mu_L}/B$，而第 12.7.3小节的 BCGD 因子相当于 $1 - \mu_L/B$，根号带来的差别在 μ_L 很小时才明显。

例中 $\mu_L = \frac{1}{4}$，$B = 2$，所以 APCG 的因子是 $1 - \frac{1}{4} = \frac{3}{4}$，BCGD 的因子是 $1 - \frac{1}{8} = \frac{7}{8}$。定理保证的都是期望，并要求块是独立均匀抽取的，单次运行的路径可能波动。

条件的作用值得逐条看。块光滑常数给出沿块的二次上界，步长由它决定；精确的块邻近求解让加速递推的不等式能闭合，若解得不准，误差会在递推中累积，第 12.7.2小节讨论的误差控制不能直接搬过来；解的存在保证 R_0 有限，否则右端没有意义。

图 12.13显示了加速的效果和代价。(a) 是链式二次目标，没有可用的强凸常数，APCG（绿）的目标差贴着虚线 t^{-2} 下降，明显快于 BCGD（黄）。(b) 是手算例子的延续，APCG 整体更快，但曲线有回升。

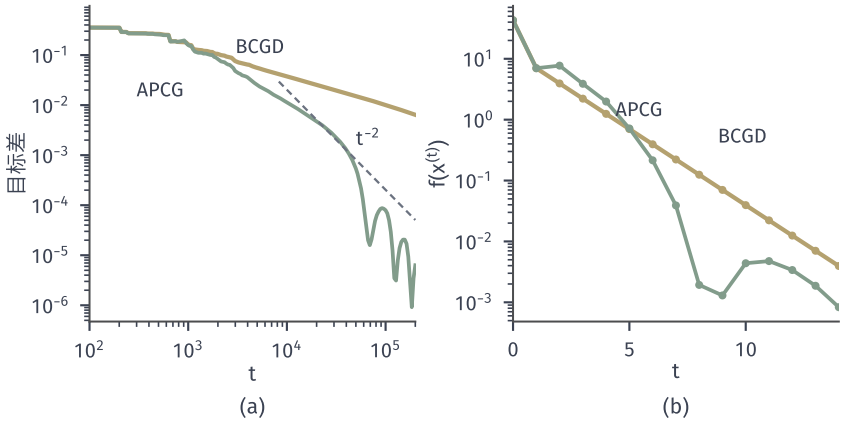


图 12.13　APCG 的数值表现。(a) 链式二次目标，$n = 200$，单坐标块，绿线是 APCG（$\mu_L = 0$），黄线是 BCGD，都是 4 次独立运行的平均，灰色虚线是斜率为 -2 的参考线。(b)$f_{3/2}$ 从 $(3,4)$ 出发，按块 $1,2,1,2,\ldots$ 的顺序，绿线是 APCG（$\alpha^{(t)} = \beta^{(t)} = \frac{1}{4}$），黄线是步长 $\frac{1}{2}$ 的 BCGD，APCG 的目标值并不单调。

计算成本　一步 APCG 除了读一个偏梯度，还要做式 (12.27)这样的全向量组合，直接实现的代价是 $O(n)$，可能抵消单坐标更新省下的计算。实现时可以把 $\boldsymbol{x}, \boldsymbol{z}$ 写成两个基向量的线性组合，组合系数是标量，每步只更新基向量的一块，外推就不必真正展开。

偏梯度读取仍然需要在 $\boldsymbol{y}^{(t)}$ 处求值。对最小二乘，维护 $\boldsymbol{A}$ 作用在两个基向量上的结果即可，每步成本和 BCGD 同量级。这一点依赖目标的结构；$\nabla_J f$ 不能增量维护时，一步的成本仍是 $O(n)$ 或更高。

12.1 分块问题
12.2 块坐标下降（BCD）
12.3 局部近似更新
12.3.1 块坐标梯度下降（BCGD）
12.3.2 加速邻近坐标梯度（APCG）
12.3.3 块坐标 Newton 法
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.8 本章小结

12.3.3 块坐标 Newton 法

主要思想 块梯度步只用一阶信息，块内变量强耦合时，它和全局梯度下降一样走折线。第 7章用 Hessian 修正方向，这里只对当前块做同样的事。设 f 二阶连续可微，把二阶 Taylor 模型限制在块 J 上：

$$m_J(\boldsymbol{h}) = f(\boldsymbol{x}) + \langle \nabla_J f(\boldsymbol{x}), \boldsymbol{h} \rangle + \frac{1}{2}\boldsymbol{h}^{\top} \boldsymbol{H}_{J,J} \boldsymbol{h},$$

其中 $\boldsymbol{H}_{J,J}$ 是 Hessian 的块 J 主子矩阵，即

$$\boldsymbol{H}_{J,J} = \boldsymbol{U}_J^{\top} \nabla^2 f(\boldsymbol{x}) \boldsymbol{U}_J.$$

$\boldsymbol{H}_{J,J}$ 正定时模型有唯一最小点，得到块 Newton 方向：

$$\boldsymbol{d}_J = -\boldsymbol{H}_{J,J}^{-1} \nabla_J f(\boldsymbol{x}). \tag{12.32}$$

块坐标 Newton 法（block coordinate Newton method）沿这个方向更新块 J，其余块不动。

正定性、修正与阻尼 第 7章对完整 Newton 法提出的三个问题，在这里同样存在，只是规模换成了块。第一是正定性：若 $\nabla^2 f(\boldsymbol{x})$ 正定，它的任何主子矩阵也正定，并且最小特征值不小于 $\nabla^2 f(\boldsymbol{x})$ 的最小特征值，块方向总是下降方向。

非凸目标的 $\boldsymbol{H}_{J,J}$ 可能不定，这时要加修正，比如把它换成 $\boldsymbol{H}_{J,J} + \tau \boldsymbol{I}$。第二是步长：二阶模型只是局部近似，不保证 $\boldsymbol{d}_J$ 上目标下降，需要沿该方向回溯，令 $\boldsymbol{x}_J^{+} = \boldsymbol{x}_J + \alpha \boldsymbol{d}_J$，用完整目标检验 α 是否可接受。第三是成本：下面单独计算。

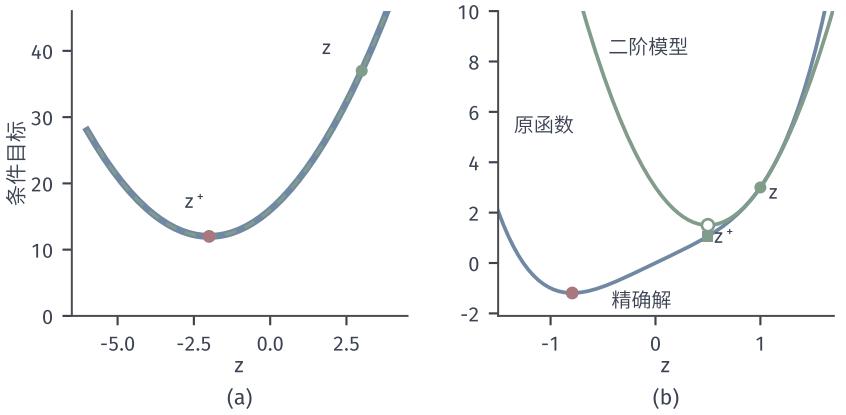
何时等于精确块解 二次目标的 $\boldsymbol{H}_{J,J}$ 是常数 $\boldsymbol{Q}_{J,J}$，二阶模型恰好等于条件函数。令 $\boldsymbol{d}_J$ 由式 (12.32)给出，$\boldsymbol{x}_J + \boldsymbol{d}_J$ 就是式 (12.8)的精确块解。

例中 $J = \{1\}$，点 $(3,4)$ 处 $\partial_1 f = 10$，$H_{1,1} = 2$，方向 $d_1 = -5$，新值 $x_1 = -2$，和精确块解相同。

一般的非线性目标则不同。设条件函数是 $\varphi(z) = z^4 + 2z$，当前 $z = 1$，则

$$\varphi'(1) = 6, \qquad \varphi''(1) = 12, \qquad z^{+} = 1 - \frac{6}{12} = 0.5.$$

而精确块解满足 $4z^3 + 2 = 0$，即 $z \approx -0.794$，两者差很远。Newton 步解的是模型，只有模型足够准确时才接近精确块解。图 12.14对比了这两种情形。



12.1 分块问题
12.2 块坐标下降（BCD）
12.3 局部近似更新
12.4 交替极小化
12.4.1 交替最小二乘（ALS）
12.4.2 逐块最优的局限
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.8 本章小结

图 12.14 块 Newton 步与精确块解。(a) 二次条件函数 $\varphi(z)=z^2+4z+16$，蓝色实线与绿色虚线分别是原函数和二阶模型，两者重合，Newton 步一步到达条件最小点。(b) 非二次条件函数 $\varphi(z)=z^4+2z$ 在 $z=1$ 处，绿色的二阶模型只在附近贴近原函数（蓝），它的最小点 $z^+=0.5$（空心点）与原函数的最小点（红）相距较远。

成本 块大小 $p=|J|$ 时，一步块 Newton 需要形成 $\boldsymbol{H}_{J,J}$ 的 $O(p^2)$ 个元素，并以约 $p^3/3$ 的运算量做 Cholesky 分解。固定其他块时若 $\boldsymbol{H}_{J,J}$ 不变，分解可以复用，这在二次目标上正是图 12.3的成本模型；一般非线性目标的 Hessian 随迭代变化，分解要反复计算。

12.4 交替极小化

前面的块多半是单个坐标或一小组坐标。有些问题的变量天然分成少数几组，每组固定其余后都容易解。沿用精确块更新依次解这几组，能得到什么，又在哪里止步？

交替极小化（alternating minimization）就是块数较少时的精确 BCD，它是组织条件求解的一种方式，并不是一类新的优化理论。下面以矩阵分解为主例，并区分三个常被混在一起的性质。分别凸使每个条件子问题容易解；块解唯一使迭代有确定含义，并支撑极限分析；联合凸才能把驻点推到全局最优。

12.4.1 交替最小二乘（ALS）

主要思想 回到矩阵分解问题

$$\min_{\boldsymbol{U},\boldsymbol{V}} \Phi(\boldsymbol{U},\boldsymbol{V})=\|\boldsymbol{Y}-\boldsymbol{U}\boldsymbol{V}^{\top}\|_F^2. \tag{12.33}$$

它关于 $(\boldsymbol{U}, \boldsymbol{V})$ 联合起来不是凸函数，但固定一个因子，另一个因子就是线性最小二乘。**交替最小二乘**（alternating least squares，ALS）轮流解这两个问题。

固定 $\boldsymbol{V}$，目标按行拆开。记 $\boldsymbol{Y}$ 的第 i 行为 $\boldsymbol{y}_i^{\top}$，$\boldsymbol{U}$ 的第 i 行为 $\boldsymbol{u}_i^{\top}$，则

$$\|\boldsymbol{Y} - \boldsymbol{U}\boldsymbol{V}^{\top}\|_F^2 = \sum_{i=1}^{p} \|\boldsymbol{y}_i - \boldsymbol{V}\boldsymbol{u}_i\|_2^2.$$

每一行都是一个系数矩阵为 $\boldsymbol{V}$ 的最小二乘问题，图 12.15(a) 标出了这种按行的结构。

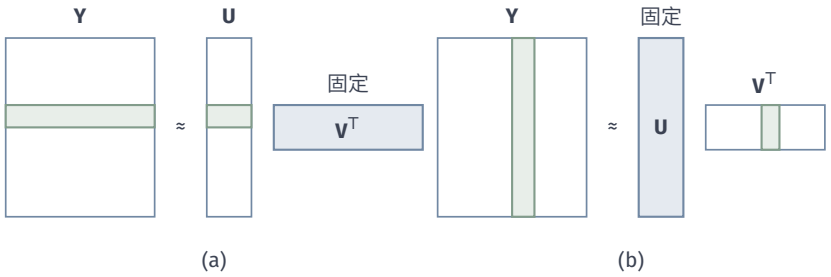


图 12.15　ALS 的两个半步。(a) 固定 $\boldsymbol{V}^{\top}$（蓝）时，$\boldsymbol{Y}$ 的每一行只依赖 $\boldsymbol{U}$ 的对应行（绿），问题拆成 p 个共用系数矩阵的最小二乘。(b) 固定 $\boldsymbol{U}$（蓝）时，$\boldsymbol{Y}$ 的每一列只依赖 $\boldsymbol{V}^{\top}$ 的对应列，同样拆开。

对 $\boldsymbol{u}_i$ 求导并把 p 行合起来，得到正规方程

$$\boldsymbol{U}\boldsymbol{V}^{\top}\boldsymbol{V} = \boldsymbol{Y}\boldsymbol{V}.$$

若 $\boldsymbol{V}$ 满列秩，$\boldsymbol{V}^{\top}\boldsymbol{V}$ 可逆，解唯一：

$$\boldsymbol{U}^{+} = \boldsymbol{Y}\boldsymbol{V}(\boldsymbol{V}^{\top}\boldsymbol{V})^{-1}. \tag{12.34}$$

同理，固定 $\boldsymbol{U}$ 且 $\boldsymbol{U}$ 满列秩时，

$$\boldsymbol{V}^{+} = \boldsymbol{Y}^{\top}\boldsymbol{U}(\boldsymbol{U}^{\top}\boldsymbol{U})^{-1}. \tag{12.35}$$

秩亏时的选解　若 $\boldsymbol{V}$ 不满列秩，正规方程有无穷多解。此时要规定选哪一个，常用的是 Frobenius 范数最小的解

$$\boldsymbol{U}^{+} = \boldsymbol{Y}\boldsymbol{V}(\boldsymbol{V}^{\top}\boldsymbol{V})^{\dagger},$$

其中 $\dagger$ 表示伪逆。比如 $\boldsymbol{V} = \boldsymbol{0}$ 时，任何 $\boldsymbol{U}$ 都使目标等于 $\|\boldsymbol{Y}\|_F^2$，这个规则选 $\boldsymbol{U} = \boldsymbol{0}$。

三种计算方式 式 (12.34)要解的是 p 个右端不同、系数相同的方程。系数矩阵是同一个，逐行重新分解是浪费，分解只需做一次。设 $\boldsymbol{V}\in\mathbb{R}^{q\times r}$，$\boldsymbol{Y}$ 稠密，一个半步的主要运算是：

- 形成 $\boldsymbol{V}^{\top}\boldsymbol{V}$，约 qr^2；形成 $\boldsymbol{Y}\boldsymbol{V}$，约 pqr。
- 做一次 Cholesky 分解，约 $r^3/3$。
- 对 p 行各做一次前代回代，约 $2pr^2$。

$\boldsymbol{Y}$ 稀疏时第二项换成 r 乘以非零元数。分解的条件数是 $\boldsymbol{V}$ 的条件数的平方，$\boldsymbol{V}$ 接近秩亏时，改用 $\boldsymbol{V}$ 的 QR 分解更稳定，但一次分解的运算量约为 $2qr^2$。

加入正则项 $\gamma(\|\boldsymbol{U}\|_F^2+\|\boldsymbol{V}\|_F^2)$，$\gamma>0$，后，系数矩阵变成严格正定，子问题总有唯一解：

$$\boldsymbol{U}^{+}=\boldsymbol{Y}\boldsymbol{V}(\boldsymbol{V}^{\top}\boldsymbol{V}+\gamma\boldsymbol{I})^{-1}. \tag{12.36}$$

秩亏的麻烦由此消除，代价是目标改变了，解被拉向零。

完整目标不增 两个半步各是一次精确块更新，由引理 12.2，连起来就是

$$\Phi(\boldsymbol{U}^{(t+1)},\boldsymbol{V}^{(t+1)})\le\Phi(\boldsymbol{U}^{(t+1)},\boldsymbol{V}^{(t)})\le\Phi(\boldsymbol{U}^{(t)},\boldsymbol{V}^{(t)}). \tag{12.37}$$

目标有下界 0，目标值序列因此收敛。注意这只说明目标值收敛，并不说明因子本身收敛，因为 $(c\boldsymbol{U},\boldsymbol{V}/c)$ 与 $(\boldsymbol{U},\boldsymbol{V})$ 有相同的目标值，因子的尺度不由目标决定。

变量

- $\boldsymbol{U}\in\mathbb{R}^{p\times r}$，$\boldsymbol{V}\in\mathbb{R}^{q\times r}$：两个因子。
- $\boldsymbol{Y}\in\mathbb{R}^{p\times q}$：数据矩阵，只读。

初始化 选定秩 r，随机初始化 $\boldsymbol{V}^{(0)}$。下面用一个 $r=1$ 的例子，因子都是向量，记为 $\boldsymbol{u},\boldsymbol{v}$：

$$\boldsymbol{Y}=\begin{bmatrix}3&1\\1&3\end{bmatrix},\qquad \boldsymbol{v}^{(0)}=(1,0),$$

于是 $\|\boldsymbol{Y}\|_F^2=20$。

每轮更新 在第 t 轮：

1. **更新 $\boldsymbol{U}$**。由式 (12.34)计算。例中 $\boldsymbol{u} = \boldsymbol{Y}\boldsymbol{v}/\|\boldsymbol{v}\|_2^2$，第一轮

$$\boldsymbol{u}^{(1)} = (3, 1), \qquad \Phi = 10.$$

2. **更新 $\boldsymbol{V}$**。由式 (12.35)计算。例中 $\boldsymbol{v} = \boldsymbol{Y}^{\top}\boldsymbol{u}/\|\boldsymbol{u}\|_2^2$，第一轮

$$\boldsymbol{v}^{(1)} = \frac{(10, 6)}{10} = (1, 0.6), \qquad \Phi = 6.4.$$

第二轮用 $\boldsymbol{v}^{(1)}$ 计算，$\|\boldsymbol{v}^{(1)}\|_2^2 = 1.36$，于是

$$\boldsymbol{u}^{(2)} = \frac{(3.6, 2.8)}{1.36} \approx (2.647, 2.059), \qquad \Phi \approx 4.706.$$

再更新 $\boldsymbol{v}$，$\|\boldsymbol{u}^{(2)}\|_2^2 \approx 11.246$，于是

$$\boldsymbol{v}^{(2)} \approx (0.889, 0.785), \qquad \Phi \approx 4.185.$$

3. **检查停止**。目标值的相对下降或因子的相对变化小于容差时结束。

第二轮的 $\boldsymbol{v}$ 两个分量之比已经接近 1，最终得到 $\boldsymbol{u}, \boldsymbol{v}$ 都平行于 $(1, 1)$，目标值趋于 4。这个 4 正是 $\boldsymbol{Y}$ 的第二个奇异值的平方，由矩阵逼近的结论，它是所有秩 1 逼近的最小误差；相关的定理可参考卷二第 18 章“矩阵逼近”。

这个例子中，交替更新实际上是幂迭代。把两个半步合起来，$\boldsymbol{v}$ 的新方向正比于 $\boldsymbol{Y}^{\top}\boldsymbol{Y}\boldsymbol{v}$，$\boldsymbol{Y}^{\top}\boldsymbol{Y}$ 的特征值是 16 和 4，所以偏离主方向的分量每轮缩小到 $\frac{1}{4}$。

图 12.16(a) 是这个例子的目标值阶梯，(b) 取一个噪声较大的 40×25 矩阵，从不同的随机起点出发，都很快接近截断奇异值分解给出的最优值。一般情形下 ALS 并不总能这样达到全局最优，下一小节就是反例。

12.1 分块问题
12.2 块坐标下降（BCD）
12.3 局部近似更新
12.4 交替极小化
12.4.1 交替最小二乘（ALS）
12.4.2 逐块最优的局限
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.8 本章小结

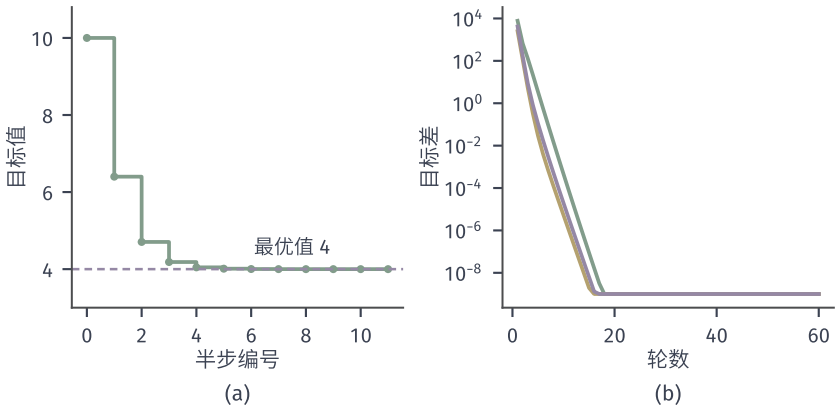


图 12.16 ALS 的目标值。(a) 文中 2×2 的例子，每半步记录一次，绿色阶梯单调下降，紫色虚线是最优秩 1 误差 4。(b)40×25 的矩阵（秩 3 信号加噪声），$r=3$，三种颜色是三个随机起点，纵轴是目标值与截断奇异值分解最优值之差，下方平台是绘图的截断值。

12.4.2 逐块最优的局限

停在鞍点的例子 每一步都精确解出了条件子问题，最后能到全局最优吗？考虑带正则的双线性目标，$0<\rho<1$：

$$\Phi_\rho(u,v)=\frac{1}{2}(uv-1)^2+\frac{\rho}{2}(u^2+v^2). \tag{12.38}$$

固定 v，它是 u 的二次函数，u^2 的系数是 $(v^2+\rho)/2>0$，所以条件子问题有唯一解。令偏导数为零，得到

$$u=\frac{v}{v^2+\rho},\qquad v=\frac{u}{u^2+\rho}. \tag{12.39}$$

这里两个条件子问题都严格凸、解唯一，看上去已经是最好的情形了。

下面取 $\rho=0.36$。全局最小点在 $u=v=\pm\sqrt{1-\rho}=\pm 0.8$，最小值是 $\rho-\rho^2/2=0.2952$。从 $v=0.6$ 出发，迭代是

$$u=0.8333,\quad v=0.7903,\quad u=0.8027,\quad v=0.7992,\quad u=0.8002,$$

目标值从 0.3148 很快降到最小值附近。

现在换一个起点：$u=v=0$。由式 (12.39)，两个更新都给出 0，迭代永远停在原点，目标值是 $\frac{1}{2}$。

原点是什么样的点？两个偏导数都是 0，它是驻点。它的 Hessian 是

$$\begin{bmatrix}\rho & -1\\ -1 & \rho\end{bmatrix},$$

特征值 $\rho - 1 = -0.64$ 和 $\rho + 1 = 1.36$ 一负一正，所以原点是鞍点，不是极小点。图 12.17画出了这一点。

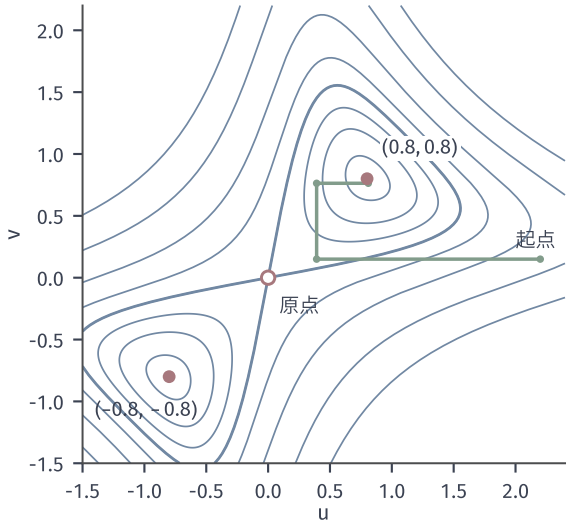


图 12.17 交替极小化与鞍点。Φ_ρ 的等高线（$\rho = 0.36$），加粗的一条是 $\Phi_\rho = \frac{1}{2}$，正好穿过原点。绿色折线从 $(2.2, 0.15)$ 出发，收敛到红点 $(0.8, 0.8)$。红色空心点是原点：两个条件子问题的解都是 0，从这里出发的迭代不动，而沿 Hessian 的负特征方向目标还能下降。

原点并不吸引路径。在原点附近 $u \approx v/\rho$，$v \approx u/\rho$，一轮下来 v 约放大 $1/\rho^2 \approx 7.7$ 倍，所以只要 v 不恰好为零，迭代就会被推开。图中的绿线就从靠近原点的横线上逃开了。不过这种稳定性分析需要另外的工作，逐块最优这个性质本身不能排除鞍点。

三个层次的对比 再把第 12.1.2小节的反例放进来，就能看清三个不同的层次。下表中，“逐块最优”指对每个块，当前点都是条件子问题的最优解。

情形	逐块最优 ⇒ 驻点?	驻点 ⇒ 全局最优?
光滑非凸（例 (12.38)）	是	否，原点是鞍点
不可分（例 (12.5)）	否，原点不是驻点	凸时为是
光滑加可分凸项，联合凸	是	是

第一列的结论：对光滑目标，每个块的偏梯度为零，合起来就是整个梯度为零，所以逐块最优蕴含驻点。可分的非光滑项也可以这样合起来。不可分的非光滑项不行，这正是例 (12.5)停滞的原因。

第二列的结论：驻点推出全局最优需要联合凸性，只是分别凸还不够。在例 (12.38)中，固定任一变量时函数都凸，联合起来却不凸。

联合凸时的结论 联合凸性加上可分结构后，上述三个层次重合，这时逐块最优就是全局最优。

> **引理 12.5 联合凸时逐块最优即全局最优** 设 $F = f + \sum_J g_J$，f 在 $\mathbb{R}^n$ 上凸且可微，各 g_J 是适当凸函数。若 $\bar{\boldsymbol{x}}$ 满足 $F(\bar{\boldsymbol{x}}) < +\infty$，且对每个块 J，$\bar{\boldsymbol{x}}_J$ 是块 J 条件子问题的最优解，则 $\bar{\boldsymbol{x}}$ 是 F 的全局最小点。

证明 取任意 $\boldsymbol{y} \in \mathbb{R}^n$，固定一块 J，令 $\boldsymbol{h} = \boldsymbol{y}_J - \bar{\boldsymbol{x}}_J$。对 $s \in (0,1]$，由块最优性，

$$f(\bar{\boldsymbol{x}} + s\boldsymbol{U}_J\boldsymbol{h}) + g_J(\bar{\boldsymbol{x}}_J + s\boldsymbol{h}) \geq f(\bar{\boldsymbol{x}}) + g_J(\bar{\boldsymbol{x}}_J).$$

由 g_J 的凸性，

$$g_J(\bar{\boldsymbol{x}}_J + s\boldsymbol{h}) \leq (1-s)g_J(\bar{\boldsymbol{x}}_J) + sg_J(\boldsymbol{y}_J),$$

代入并整理得

$$\frac{f(\bar{\boldsymbol{x}} + s\boldsymbol{U}_J\boldsymbol{h}) - f(\bar{\boldsymbol{x}})}{s} + g_J(\boldsymbol{y}_J) - g_J(\bar{\boldsymbol{x}}_J) \geq 0.$$

令 $s \downarrow 0$，第一项趋于 $\langle \nabla_J f(\bar{\boldsymbol{x}}), \boldsymbol{h} \rangle$，于是

$$\langle \nabla_J f(\bar{\boldsymbol{x}}), \boldsymbol{y}_J - \bar{\boldsymbol{x}}_J \rangle + g_J(\boldsymbol{y}_J) - g_J(\bar{\boldsymbol{x}}_J) \geq 0.$$

对所有块求和。f 是凸函数，所以

$$f(\boldsymbol{y}) \geq f(\bar{\boldsymbol{x}}) + \langle \nabla f(\bar{\boldsymbol{x}}), \boldsymbol{y} - \bar{\boldsymbol{x}} \rangle,$$

于是

$$\begin{aligned} F(\boldsymbol{y}) - F(\bar{\boldsymbol{x}}) &\geq \langle \nabla f(\bar{\boldsymbol{x}}), \boldsymbol{y} - \bar{\boldsymbol{x}} \rangle + \sum_J \big(g_J(\boldsymbol{y}_J) - g_J(\bar{\boldsymbol{x}}_J) \big) \\ &\geq 0. \end{aligned}$$

■

证明中用到可分结构的地方是把各块的不等式相加。这正好解释了例 (12.5)为什么失败：它的非光滑项不能写成 $\sum_J g_J(\boldsymbol{x}_J)$，两块的不等式加不到一起。

12.1 分块问题
12.2 块坐标下降（BCD）
12.3 局部近似更新
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.5.1 块上界的条件
12.5.2 上界的构造
12.5.3 与其他块方法的关系
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.8 本章小结

12.5 块上界最小化（BSUM）

前面几种更新（精确块解、块梯度步）看起来不同，下降的理由却相似：都在当前块上最小化一个不低于原目标、在当前点贴住原目标的函数。于是要问：这样的函数需要满足什么条件，才能保证完整目标的进展？

第 11章的 MM 方法对全部变量最小化上界，**块上界最小化**（block successive upper-bound minimization，BSUM）把同样的想法用在块上。它研究的是代理模型的构造和保证，可以覆盖好几种前面的更新，并不限于精确交替求解。

12.5.1 块上界的条件

框架 设 $F:\boldsymbol{C}\to\mathbb{R}$，$\boldsymbol{C}$ 是闭凸集的乘积 (12.4)。对每个块 J 和当前点 $\boldsymbol{y}\in\boldsymbol{C}$，取一个定义在 $\boldsymbol{C}_J$ 上的函数 $u_J(\cdot;\boldsymbol{y})$，每次选块 J 后最小化它：

$$\boldsymbol{x}_J^{(t+1)}\in\operatorname*{arg\,min}_{\boldsymbol{z}\in\boldsymbol{C}_J}u_J(\boldsymbol{z};\boldsymbol{x}^{(t)}),\qquad \boldsymbol{x}_i^{(t+1)}=\boldsymbol{x}_i^{(t)}\ (i\notin J). \tag{12.40}$$

直观地说，这是在目标上方扣一只贴住当前点的碗。碗不低于目标，碗底不高于当前点，所以从碗底的位置看，目标一定没有升高。好的 u_J 既要比条件函数容易最小化，又要真正起到这只碗的作用。下面的定义列出了所需的条件。

定义 12.6 块上界 称 u_J 是块 J 的**块上界**（block upper bound），如果对一切 $\boldsymbol{y}\in\boldsymbol{C}$ 和 $\boldsymbol{z}\in\boldsymbol{C}_J$，以及一切满足 $\boldsymbol{y}_J+\boldsymbol{d}\in\boldsymbol{C}_J$ 的方向 $\boldsymbol{d}$，下列条件成立：

$$u_J(\boldsymbol{y}_J;\boldsymbol{y})=F(\boldsymbol{y}), \tag{12.41}$$

$$u_J(\boldsymbol{z};\boldsymbol{y})\geq F\big(\boldsymbol{y}+\boldsymbol{U}_J(\boldsymbol{z}-\boldsymbol{y}_J)\big), \tag{12.42}$$

$$u_J'(\boldsymbol{y}_J;\boldsymbol{y};\boldsymbol{d})=F'(\boldsymbol{y};\boldsymbol{U}_J\boldsymbol{d}), \tag{12.43}$$

其中左端的方向导数对第一个变量取，且 u_J 关于 $(\boldsymbol{z},\boldsymbol{y})$ 连续。

条件的作用 式 (12.42)是上界条件，式 (12.41)是当前点相等的条件，两者合起来给出下降：

$$F(\boldsymbol{x}^{(t+1)})\leq u_J(\boldsymbol{x}_J^{(t+1)};\boldsymbol{x}^{(t)})\leq u_J(\boldsymbol{x}_J^{(t)};\boldsymbol{x}^{(t)})=F(\boldsymbol{x}^{(t)}). \tag{12.44}$$

第一个不等号用上界，第二个不等号用 $\boldsymbol{x}_J^{(t+1)}$ 是最小点，等号用当前点相等。

一阶条件 (12.43)不是用来保证下降的，而是让停下来的点有意义。如果迭代在 $\boldsymbol{y}_J$ 不动，说明 $\boldsymbol{y}_J$ 最小化了 u_J，那么 u_J 在 $\boldsymbol{y}_J$ 的方向导数非负；有了一阶条件，F 沿块方向的方向导数也非负。连续性则让这些性质能够传到极限点。

去掉条件会怎样 图 12.18用同一个条件函数说明。当前点是 $z = 2$。(a) 是合格的二次上界。

(b) 是二阶 Taylor 模型，曲率取真实值 $\varphi''(2) \approx 0.089$。它不是上界，最小点在 $z \approx -2.41$，模型预测目标值大幅下降，实际 $\varphi(-2.41) \approx 3.81$ 却远高于当前值 1.24。上界条件被破坏，下降链断了。

(c) 是上界 $\varphi(2) + 1.5|z - 2|$。因为 $|\varphi'| \le 1.5$，它确实是上界，并且在当前点相等，于是满足前两个条件。但它在 $z = 2$ 处有尖角，最小点就是当前点，算法不动，而 $\varphi'(2) \neq 0$。这说明缺了一阶条件，下降虽然仍然成立，却可以停在任何点上。

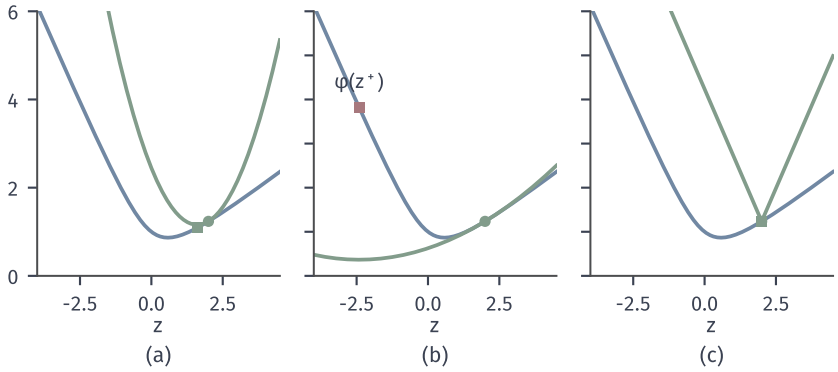


图 12.18 块上界的三个条件。蓝色是条件函数 $\varphi(z) = \sqrt{1 + z^2} - z/2$，绿色是模型，绿点是当前点 $z = 2$，方块是模型最小点上原函数的值。(a) 二次上界满足全部条件。(b) 二阶 Taylor 模型不是上界，最小点走得太远，红色方块处的目标值反而升高。(c) 带尖角的上界满足上界与相等条件，但方向导数不一致，最小点就是当前点。

上界要覆盖全部允许变化 上界必须在整个 $\boldsymbol{C}_J$ 上成立，因为子问题的解可能落在 $\boldsymbol{C}_J$ 的任何位置。只在当前点附近成立的局部近似，比如 (b) 中的 Taylor 模型，不能用式 (12.44)这条链。

这时要另外控制接受：用线搜索沿模型方向检验真实目标，或用第 9章的信赖域限制模型的使用范围。这两种机制是用额外的函数值检验来替代上界保证。

12.1 分块问题
12.2 块坐标下降（BCD）
12.3 局部近似更新
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.5.1 块上界的条件
12.5.2 上界的构造
12.5.3 与其他块方法的关系
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.8 本章小结

12.5.2 上界的构造

一阶上界 第一种构造用光滑项的二次上界。设 $F = f$ 可微，且满足定义 12.3，取

$$u_J(\boldsymbol{z};\boldsymbol{y}) = f(\boldsymbol{y}) + \langle \nabla_J f(\boldsymbol{y}), \boldsymbol{z} - \boldsymbol{y}_J \rangle + \frac{L_J}{2}\|\boldsymbol{z} - \boldsymbol{y}_J\|_2^2. \tag{12.45}$$

上界条件来自式 (12.17)，相等和一阶条件可以直接核对。子问题有闭式解，难解的条件函数换成了一个球形的二次函数。

再看前面的条件函数 $\varphi(z) = \sqrt{1+z^2} - z/2$，$L_J = 1$，$z = 2$。原条件问题要解 $z/\sqrt{1+z^2} = \frac{1}{2}$，模型的最小点却只要一次减法：

$$z^+ = 2 - \varphi'(2) \approx 1.606.$$

下降链 (12.44)在这里的数值是

$$\varphi(z^+) \approx 1.089 \le u(z^+) \approx 1.158 \le u(2) = \varphi(2) \approx 1.236.$$

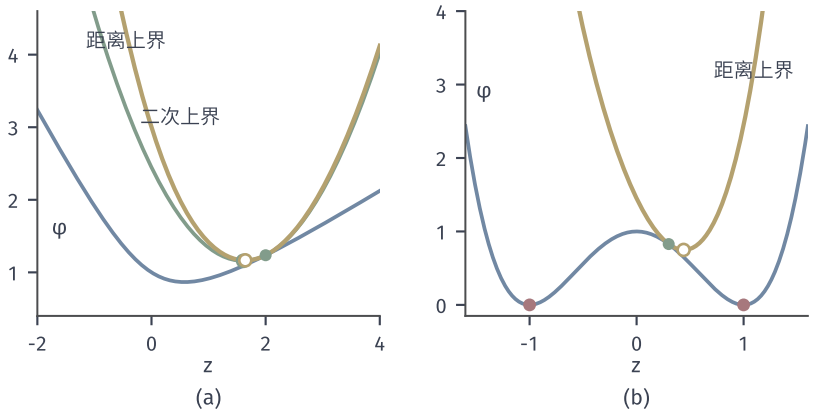
保留原目标加距离项 第二种构造不改变原条件函数，只在外面加一个二次距离项，$\beta > 0$：

$$u_J(\boldsymbol{z};\boldsymbol{y}) = F\big(\boldsymbol{y} + \boldsymbol{U}_J(\boldsymbol{z} - \boldsymbol{y}_J)\big) + \frac{\beta}{2}\|\boldsymbol{z} - \boldsymbol{y}_J\|_2^2. \tag{12.46}$$

距离项非负，所以它不低于条件函数；在当前点距离项为零，两者相等；距离项在当前点的方向导数为零，所以一阶条件也成立。这种构造不简化子问题，但改善了子问题的结构。

二次项的作用有两种。一是控制曲率：条件函数的曲率有负的下界 $-\sigma$ 时，取 $\beta > \sigma$，子问题就变成强凸的。二是改善唯一性：第 12.7.3小节的极限分析要求子问题的解唯一，距离项能把多解的子问题变成单解。

图 12.19(b) 取 $\varphi(z) = (z^2-1)^2$，它有两个最小点 ± 1，曲率下界是 -4。在 $z = 0.3$ 处取 $\beta = 10$，模型变成强凸，只有一个最小点，约在 0.44。



12.1 分块问题
12.2 块坐标下降（BCD）
12.3 局部近似更新
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.5.1 块上界的条件
12.5.2 上界的构造
12.5.3 与其他块方法的关系
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.8 本章小结

图 12.19 两种块上界的构造。(a)$\varphi(z)=\sqrt{1+z^2}-z/2$（蓝）在 $z=2$ 处的二次上界（绿，$L_J=1$）和保留原函数的距离上界（黄，$\beta=1$），空心点是各自的最小点。(b) 非凸函数 $\varphi(z)=(z^2-1)^2$ 有两个最小点（红），在绿点 $z=0.3$ 处加上 $\frac{10}{2}(z-0.3)^2$ 后，距离上界（黄）只有一个最小点（空心）。

通向块邻近模型 第三种构造介于两者之间。设目标 $F=f+\sum_J g_J$，光滑项 f 用二次上界代替，可分的非光滑项 g_J 原样保留。这样子问题既保留了 g_J 的结构，又不必处理 f 的复杂形式，这就是第 12.6节的块邻近模型。

12.5.3 与其他块方法的关系

把各种更新放进 BSUM 的框架，能看清谁是谁的特例，也能看清谁不是。图 12.20汇总了这些关系。

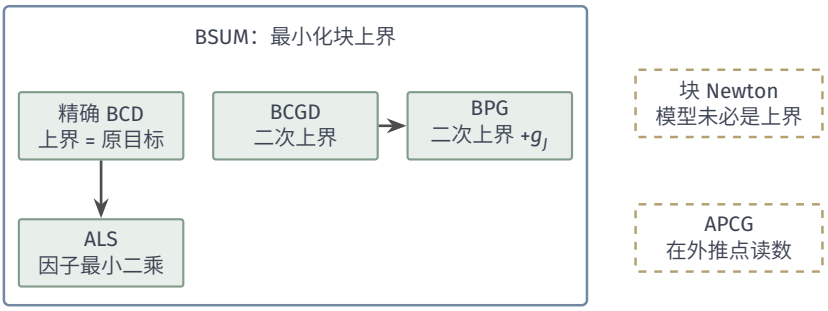


图 12.20 BSUM 与其他块方法的关系。实线框内是满足块上界条件的更新：精确 BCD 的上界是条件函数本身，BCGD 用二次上界，BPG 再保留可分项 g_J，ALS 是因子问题上的精确 BCD。黄色虚线框的两种方法一般不满足这些条件，不能未经核验就使用 BSUM 的下降与收敛保证。

属于 BSUM 的情形 当 u_J 就是条件函数时，式 (12.40)就是精确 BCD。取式 (12.45)得到 BCGD。下一节的块邻近梯度取光滑部分的二次上界加 g_J。ALS 是因子问题上的精确求解，所以也在框内，但它的关键在于因子结构带来的闭式最小二乘，这一点并不是 BSUM 框架提供的。

12.1 分块问题
12.2 块坐标下降（BCD）
12.3 局部近似更新
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.6.1 块邻近更新
12.6.2 块邻近残差
12.7 实现与收敛
12.8 本章小结

这些关系是按模型的选择和问题的结构形成的交叉,而不是一棵分类树。同一个算法可以从几种角度描述。比如对二次目标，式 (12.45)取 $L_J = Q_{J,J}$（单坐标）时，BCGD 和精确 BCD 就是同一个更新。

不属于 BSUM 的情形 一般的块 Newton 模型不是上界，图 12.18(b) 已经说明，它需要线搜索或信赖域来保证接受。只有当二阶模型恰好被改造成上界时（比如把 Hessian 主子矩阵换成一个不小于真实 Hessian 的矩阵），才回到 BSUM。

APCG 的模型建立在外推点上，式 (12.44)这样的单调链不成立，手算例子中目标值也确实上升过。它的收敛结论靠的是辅助序列的递推，定理 12.4不能由 BSUM 的结论推出。

12.6 块邻近梯度（BPG）

许多目标是光滑项加上按块可分的非光滑项，例如最小二乘加 ℓ_1 正则。接下来要弄清：怎样在一块上同时利用光滑项的梯度和非光滑项的结构，并判断算法何时可以停下来？

设目标是式 (12.24)的形式，g_J 是适当、下半连续的凸函数。第 11章已经对完整变量建立了邻近梯度法，这里集中说明分块之后什么地方变了：可分性让邻近映射能逐块计算，步长由块常数决定，残差的含义也不同。第 12.3.2小节的 APCG 是在同样的复合结构上另配了加速递推。

12.6.1 块邻近更新

主要思想 在块 J 上，用二次上界代替光滑项，原样保留非光滑项，得到模型

$$u_J(\boldsymbol{z};\boldsymbol{x}) = f(\boldsymbol{x}) + \langle \nabla_J f(\boldsymbol{x}), \boldsymbol{z}-\boldsymbol{x}_J\rangle + \frac{L_J}{2}\|\boldsymbol{z}-\boldsymbol{x}_J\|_2^2 + g_J(\boldsymbol{z}) + \sum_{i\neq J} g_i(\boldsymbol{x}_i). \tag{12.47}$$

其中只有 $\boldsymbol{z}$ 是变量。对前三项配方，最小化 u_J 等价于

$$\min_{\boldsymbol{z}}\ g_J(\boldsymbol{z}) + \frac{L_J}{2}\left\|\boldsymbol{z} - \left(\boldsymbol{x}_J - \frac{1}{L_J}\nabla_J f(\boldsymbol{x})\right)\right\|_2^2,$$

这正是邻近映射的定义。于是**块邻近梯度**（block proximal gradient, BPG）的更新是块梯度步接邻近映射：

$$\boldsymbol{x}_J^+ = \operatorname{prox}_{g_J/L_J}\left(\boldsymbol{x}_J - \frac{1}{L_J}\nabla_J f(\boldsymbol{x})\right). \tag{12.48}$$

g_J 是闭凸集 $\boldsymbol{C}_J$ 的示性函数时，邻近映射就是到 $\boldsymbol{C}_J$ 的投影，式 (12.48)成为块投影梯度步，第 12.1.2小节的乘积可行域由此纳入同一框架。

完整目标不增 步长取块常数的倒数，邻近映射精确计算，就有下面的下降量。

引理 12.7 块邻近步的下降量 设 f 可微且满足定义 12.3，g_J 是适当、下半连续的凸函数，$F(\boldsymbol{x}) < +\infty$。按式 (12.48)更新块 J，其余块不变，得到 $\boldsymbol{x}^+$。则

$$F(\boldsymbol{x}) - F(\boldsymbol{x}^+) \geq \frac{L_J}{2}\|\boldsymbol{x}_J^+ - \boldsymbol{x}_J\|_2^2. \tag{12.49}$$

证明 由式 (12.17)，u_J 是块上界，所以 $F(\boldsymbol{x}^+) \leq u_J(\boldsymbol{x}_J^+; \boldsymbol{x})$。模型的光滑部分带系数 $L_J/2$，g_J 凸，所以 u_J 关于 $\boldsymbol{z}$ 是 L_J 强凸的。

$\boldsymbol{x}_J^+$ 是 u_J 的最小点，强凸性给出：对任意 $\boldsymbol{z}$，

$$u_J(\boldsymbol{z}; \boldsymbol{x}) \geq u_J(\boldsymbol{x}_J^+; \boldsymbol{x}) + \frac{L_J}{2}\|\boldsymbol{z} - \boldsymbol{x}_J^+\|_2^2.$$

取 $\boldsymbol{z} = \boldsymbol{x}_J$，并由 $u_J(\boldsymbol{x}_J; \boldsymbol{x}) = F(\boldsymbol{x})$，得到

$$F(\boldsymbol{x}) \geq u_J(\boldsymbol{x}_J^+; \boldsymbol{x}) + \frac{L_J}{2}\|\boldsymbol{x}_J - \boldsymbol{x}_J^+\|_2^2 \geq F(\boldsymbol{x}^+) + \frac{L_J}{2}\|\boldsymbol{x}_J - \boldsymbol{x}_J^+\|_2^2.$$

■

若步长取得比 $1/L_J$ 大，u_J 就可能不再是上界，下降量不再有保证。这里的“精确”也不是可有可无的条件：邻近子问题解得不准时，要按第 12.7.2小节计入误差。

计算过程：套索的单坐标更新 考虑套索问题，$\gamma > 0$，取最小二乘的光滑项和 ℓ_1 正则：

$$F(\boldsymbol{x}) = \frac{1}{2}\|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|_2^2 + \gamma\|\boldsymbol{x}\|_1.$$

取坐标为块，$g_j = \gamma|\cdot|$ 可分，$\gamma|\cdot|/L_j$ 的邻近映射是软阈值

$$S_\tau(v) = \operatorname{sign}(v)\max\{|v| - \tau, 0\}, \qquad \tau = \frac{\gamma}{L_j}. \tag{12.50}$$

于是式 (12.48)成为

$$x_j^+ = S_{\gamma/L_j}\Big(x_j - \frac{1}{L_j}\boldsymbol{a}_j^\top \boldsymbol{r}\Big), \qquad L_j = \|\boldsymbol{a}_j\|_2^2. \tag{12.51}$$

这时光滑项的条件函数是抛物线，上界等于它，式 (12.51)也是精确块解。

变量

- $\boldsymbol{x}$：当前系数；$\boldsymbol{r} = \boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}$：残差，每次更新后维护。
- L_j：各列的平方范数，事先算好；γ：正则系数。

初始化 下面用与前面相同的 $\boldsymbol{A}$，并取以下数据进行演示：

$$\boldsymbol{b} = (4, 2, -1), \qquad \gamma = 1, \qquad \boldsymbol{x}^{(0)} = (3, 4).$$

于是 $L_1 = L_2 = 2$，阈值 $\tau = \frac{1}{2}$，初始残差 $\boldsymbol{r} = (3, 1, 5)$，目标值 $F = 24.5$。

每轮更新 循环取坐标 $j = 1, 2$，每次按式 (12.51)更新 x_j，再更新残差 $\boldsymbol{r} \leftarrow \boldsymbol{r} + (x_j^{+} - x_j)\boldsymbol{a}_j$。

1. 第一轮，$j = 1$：$\boldsymbol{a}_1^{\top}\boldsymbol{r} = 4$，软阈值的输入是 $3 - 2 = 1$，于是

$$x_1 = 0.5, \qquad \boldsymbol{r} = (0.5, -1.5, 5), \qquad F = 18.25.$$

2. 第一轮，$j = 2$：$\boldsymbol{a}_2^{\top}\boldsymbol{r} = 5.5$，输入是 $4 - 2.75 = 1.25$，于是

$$x_2 = 0.75, \qquad \boldsymbol{r} = (-2.75, -1.5, 1.75), \qquad F = 7.6875.$$

3. 第二轮，$j = 1$：$\boldsymbol{a}_1^{\top}\boldsymbol{r} = -4.25$，输入是 $0.5 + 2.125 = 2.625$，于是

$$x_1 = 2.125, \qquad \boldsymbol{r} = (-1.125, 0.125, 1.75), \qquad F = 5.046875.$$

4. 第二轮，$j = 2$：$\boldsymbol{a}_2^{\top}\boldsymbol{r} = 0.625$，输入是 $0.75 - 0.3125 = 0.4375$，小于阈值，于是

$$x_2 = 0, \qquad \boldsymbol{r} = (-1.875, 0.125, 1), \qquad F = 4.390625.$$

5. 第三轮，$j = 1$：$\boldsymbol{a}_1^{\top}\boldsymbol{r} = -1.75$，输入是 $2.125 + 0.875 = 3$，于是

$$x_1 = 2.5, \qquad \boldsymbol{r} = (-1.5, 0.5, 1), \qquad F = 4.25.$$

6. 第三轮，$j = 2$：$\boldsymbol{a}_2^{\top}\boldsymbol{r} = -0.5$，输入是 $0 + 0.25 = 0.25$，仍小于阈值，x_2 保持为 0。

此时两个坐标都不再变化，迭代结束，最终得到 $\boldsymbol{x} = (2.5, 0)$，$F = 4.25$。图 12.21(a) 是软阈值函数，(b) 是这条路径。第二轮之后 x_2 被压到 0 并留在那里，这就是 ℓ_1 正则产生稀疏解的方式。

12.1 分块问题
12.2 块坐标下降（BCD）
12.3 局部近似更新
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.6.1 块邻近更新
12.6.2 块邻近残差
12.7 实现与收敛
12.8 本章小结

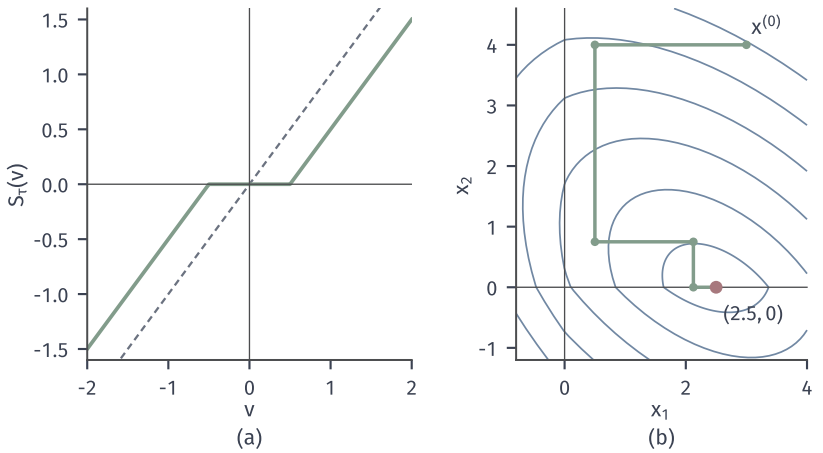


图 12.21 套索的坐标更新。(a) 软阈值函数 $S_{1/2}(v)$（绿），灰色虚线是恒等映射，$|v| \le \frac{1}{2}$ 的输入被压成 0。(b) 文中的例子：蓝色是复合目标的等高线，绿色折线是循环更新的路径，第二轮把 x_2 压到坐标轴上，红点是解 $(2.5, 0)$。

可分性的边界 上面每一步能单独计算,靠的是非光滑项能拆成 $\sum_j g_j(x_j)$。对式 (12.5)这样的不可分项，把一块的条件函数写出来仍是可以的，比如固定 v 后对 u 的邻近子问题，但它的结果依赖其他块，算法也就可能如第 12.1.2小节那样停滞。逐块计算的前提和逐块最优性能合成整体驻点的前提，是同一个可分性。

12.6.2 块邻近残差

要回答的问题 光滑时用偏梯度判断一块是否调好了。有非光滑项时偏梯度不再归零，比如解 $(2.5, 0)$ 处第二个坐标的偏导数是 -0.5，不是 0，该坐标却已经最优。需要一个既能处理非光滑项又能计算的量。

定义 12.8 块梯度映射 设 $\alpha > 0$，定义块 J 的**块梯度映射**（block gradient mapping）为

$$\boldsymbol{G}_J(\boldsymbol{x}) = \frac{1}{\alpha}\Big(\boldsymbol{x}_J - \operatorname{prox}_{\alpha g_J}\big(\boldsymbol{x}_J - \alpha \nabla_J f(\boldsymbol{x})\big)\Big). \tag{12.52}$$

它是块邻近步的位移除以步长。$g_J \equiv 0$ 时就是偏梯度 $\nabla_J f(\boldsymbol{x})$，所以它是偏梯度的自然推广。

全部为零即复合驻点 由邻近映射的最优性条件可以读出这个量的含义。记 $\boldsymbol{p} = \operatorname{prox}_{\alpha g_J}(\boldsymbol{v})$，则 $\boldsymbol{p}$ 满足 $(\boldsymbol{v} - \boldsymbol{p})/\alpha \in \partial g_J(\boldsymbol{p})$，其中 ∂g_J 是次微分。取 $\boldsymbol{v} = \boldsymbol{x}_J - \alpha \nabla_J f(\boldsymbol{x})$，$\boldsymbol{G}_J(\boldsymbol{x}) = \boldsymbol{0}$ 就是 $\boldsymbol{p} = \boldsymbol{x}_J$，代入得到

$$-\nabla_J f(\boldsymbol{x}) \in \partial g_J(\boldsymbol{x}_J).$$

反过来，若上式成立，$\boldsymbol{x}_J$ 满足邻近子问题的最优性条件，邻近映射的解唯一，所以 $\boldsymbol{p} = \boldsymbol{x}_J$。

因此全部块的映射同时为零，等价于每块都有 $-\nabla_J f(\boldsymbol{x}) \in \partial g_J(\boldsymbol{x}_J)$。由 g 按块可分，次微分是各块次微分的乘积，上面 B 个包含关系合起来就是

$$\mathbf{0} \in \nabla f(\boldsymbol{x}) + \partial g(\boldsymbol{x}). \tag{12.53}$$

这是复合目标的驻点条件。f 凸时，由引理 12.5的论证，它也是全局最优条件。

刚更新块的残差 实际运行中还有一个容易出错的地方：不要拿刚更新块的残差代替完整残差。例中取 $\alpha = \frac{1}{2}$，看前两步的残差，其中 $\boldsymbol{G}_J$ 的值都按更新后的点重新计算：

$$\begin{aligned} \boldsymbol{x} = (3,4): &\quad G_1 = 5, \quad G_2 = 8, \\ \boldsymbol{x} = (0.5,4): &\quad G_1 = 0, \quad G_2 = 6.5, \\ \boldsymbol{x} = (0.5,0.75): &\quad G_1 = -3.25, \quad G_2 = 0. \end{aligned}$$

第二行刚更新了 x_1，G_1 变成 0。但第三行更新 x_2 之后，G_1 又变成了 -3.25：x_1 在新的 x_2 下不再是最优的。

一块的残差只反映这一块在当时的状况，其他块一变，先前算出的残差就过期了。完整驻点残差要求所有块在同一点上重新计算，停止准则应当用它，或者至少在一轮结束后重算一次。

图 12.22对比了两个量。黄点是每次更新前对被更新块算出的残差，绿线是当时所有块的完整残差。黄点常常比绿线小一到两个数量级，个别的还接近零，这时只看单块残差就会过早停止。

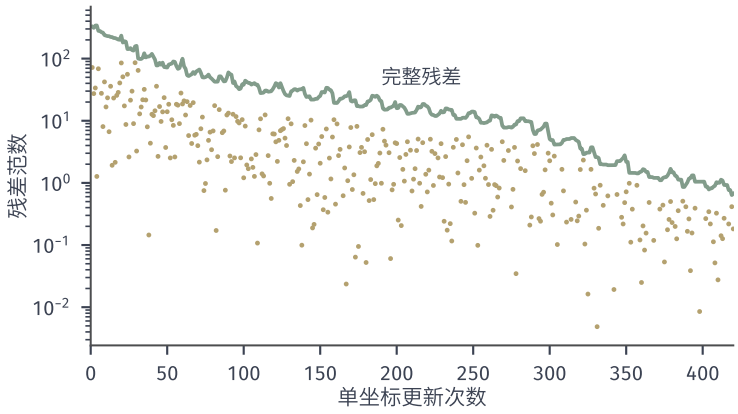


图 12.22 单块残差与完整残差。$N = 60$、$n = 30$ 的套索问题（列之间相关，$\gamma = 2$），循环单坐标更新 14 轮。绿线是全部块的残差范数，黄点是每次被更新那一块在更新前的残差绝对值（$\alpha = 1/L_j$）。残差为零的点因对数坐标未画出。

12.7 实现与收敛

12.1 分块问题
12.2 块坐标下降（BCD）
12.3 局部近似更新
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.7.1 串行与并行
12.7.2 子问题的求解精度
12.7.3 收敛保证
12.7.4 计算成本
12.8 本章小结

前面几节给出了更新公式。本节把它们放回实际运行的环境，回答：更新怎样读值，内层要解到多准，算法能保证什么，总计算量是否真的省了？下面的结论都与具体的选块规则、模型条件和误差要求绑定，评价进展时统一看完整目标。

12.7.1 串行与并行

串行读新值，并行读旧值 串行时，每一块读取的都是已经更新过的最新值。并行时，多块基于同一个旧点同时计算，然后同时写入。这看起来只差一点，实际上改变了算法的性质：串行步长的保证建立在“只有一块变化”上，而并行时变化的是几块的和。

用最小的例子看。目标是

$$f(u,v)=\frac{1}{2}(u+v)^2,\qquad (u,v)=(1,1).$$

每个坐标的块光滑常数都是 1。串行时，先更新 u，得 $u=1-2=-1$，到达 $(-1,1)$，目标值 0，已经最优。

并行时，两个坐标都读 $u+v=2$，都走同样的一步，得到

$$(u,v)=(1,1)-(2,2)=(-1,-1),$$

目标值仍是 2。下一步又回到 $(1,1)$，迭代在这两点之间振荡，永远不动。每一块单独都沿下降方向走，合起来却越过了最低点。图 12.23(a) 是这条路径。

覆盖同时变化的联合上界 上界 (12.17)只对一块变化成立。要保证并行步，需要一个覆盖几块同时变化的上界。下面的引理说明，对凸目标，只需把步长缩小到同时更新块数的倒数。

引理 12.9 并行更新的联合上界 设 f 是凸函数，且满足定义 12.3。$\mathcal{S}$ 是含 τ 个块的集合，$\boldsymbol{h}_J\in\mathbb{R}^{|J|}$ $(J\in\mathcal{S})$。则

$$f\Big(\boldsymbol{x}+\sum_{J\in\mathcal{S}}\boldsymbol{U}_J\boldsymbol{h}_J\Big)\le f(\boldsymbol{x})+\sum_{J\in\mathcal{S}}\langle\nabla_J f(\boldsymbol{x}),\boldsymbol{h}_J\rangle+\frac{\tau}{2}\sum_{J\in\mathcal{S}}L_J\|\boldsymbol{h}_J\|_2^2.\quad(12.54)$$

证明　把位移写成 τ 个块方向的平均：

$$\boldsymbol{x} + \sum_{J \in \mathcal{S}} \boldsymbol{U}_J \boldsymbol{h}_J = \frac{1}{\tau} \sum_{J \in \mathcal{S}} \big(\boldsymbol{x} + \tau \boldsymbol{U}_J \boldsymbol{h}_J \big).$$

由 f 的凸性，

$$f\Big(\boldsymbol{x} + \sum_{J \in \mathcal{S}} \boldsymbol{U}_J \boldsymbol{h}_J \Big) \le \frac{1}{\tau} \sum_{J \in \mathcal{S}} f\big(\boldsymbol{x} + \tau \boldsymbol{U}_J \boldsymbol{h}_J \big).$$

对每一项用上界 (12.17)，位移取 $\tau \boldsymbol{h}_J$：

$$f\big(\boldsymbol{x} + \tau \boldsymbol{U}_J \boldsymbol{h}_J \big) \le f(\boldsymbol{x}) + \tau \langle \nabla_J f(\boldsymbol{x}), \boldsymbol{h}_J \rangle + \frac{L_J \tau^2}{2} \|\boldsymbol{h}_J\|_2^2.$$

代入后除以 τ，即得式 (12.54)。 ■

式 (12.54)的右边对各块可分，分别最小化，得到每块的并行步长 $1/(\tau L_J)$，并且保证下降量至少是

$$\frac{1}{2\tau} \sum_{J \in \mathcal{S}} \frac{\|\nabla_J f(\boldsymbol{x})\|_2^2}{L_J}. \tag{12.55}$$

例中 $\tau = 2$，步长是 $\frac{1}{2}$，两个坐标都走 -1，一步到 $(0, 0)$。

这个因子 τ 偏保守。对最小二乘，若 $\boldsymbol{A}$ 的每一行最多有 ω 个非零元，由 Cauchy–Schwarz 不等式，第 i 行满足

$$\Big(\sum_{j} a_{i,j} h_j \Big)^2 \le \omega \sum_{j} a_{i,j}^2 h_j^2.$$

对所有行求和，二次项不超过 $\omega \sum_j L_j h_j^2$，所以因子可以取 $\min\{\tau, \omega\}$。变量之间的耦合越稀疏，并行越接近串行的效率。例中 $\boldsymbol{A}$ 的第一行有两个非零元，$\omega = 2$。

图 12.23(b) 是三变量的例子，$\boldsymbol{Q} = 0.25\boldsymbol{I} + 0.75\,\boldsymbol{1}\boldsymbol{1}^{\top}$。串行步长 $\alpha = 1$（$L_j = 1$）用于并行时目标值发散，缩小到 $\alpha = \frac{1}{3}$ 后单调下降，但慢于串行。

12.1 分块问题
12.2 块坐标下降（BCD）
12.3 局部近似更新
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.7.1 串行与并行
12.7.2 子问题的求解精度
12.7.3 收敛保证
12.7.4 计算成本
12.8 本章小结

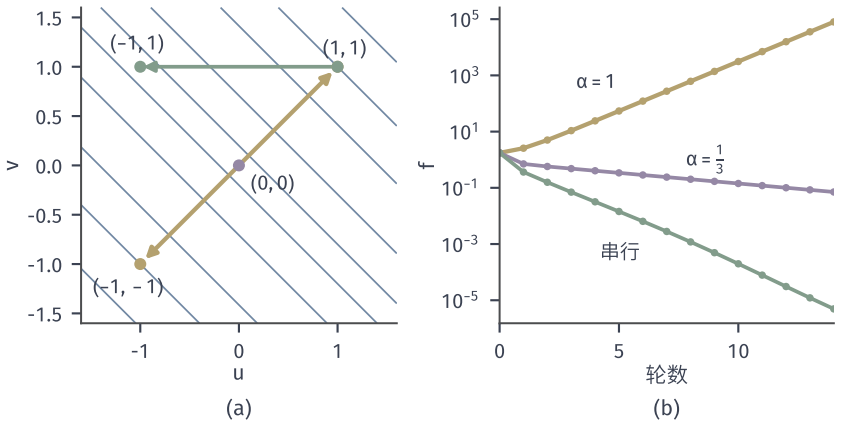


图 12.23 串行与并行。(a)$f = \frac{1}{2}(u+v)^2$ 从 $(1,1)$ 出发：绿色是串行一步到达 $(-1,1)$；黄色是并行且步长 1，在 $(1,1)$ 与 $(-1,-1)$ 间振荡；紫点是并行且步长 $\frac{1}{2}$ 的结果 $(0,0)$。(b)$n=3$、$\boldsymbol{Q} = 0.25\boldsymbol{I} + 0.75\mathbf{1}\mathbf{1}^{\top}$ 时目标值随轮数的变化：黄线是并行且步长 1，紫线是并行且步长 $\frac{1}{3}$，绿线是串行且步长 1。

实现条件 同步并行要在每轮末等所有块写完，这一等待有实际的时间成本。共享残差时，多个块同时写 $\boldsymbol{r}$ 要处理写冲突；块的数据不重叠时才能完全并行。若不做同步，块会读到别的块更新到一半的旧值，这时上面的引理不再适用，需要另外分析读取延迟。

12.7.2 子问题的求解精度

把误差计入下降量 块子问题常常只能迭代求解。设 m 是当前块的模型（精确 BCD 时就是条件函数），$\boldsymbol{z}^{\star}$ 是模型的最小点。近似解 $\tilde{\boldsymbol{z}}$ 的模型值误差为

$$m(\tilde{\boldsymbol{z}}) \le m(\boldsymbol{z}^{\star}) + \varepsilon. \tag{12.56}$$

若 m 是块上界，由上界与相等条件，近似解带来的完整目标下降至少是

$$F(\boldsymbol{x}) - F(\boldsymbol{x}^{+}) \ge \big(m(\boldsymbol{x}_J) - m(\boldsymbol{z}^{\star})\big) - \varepsilon. \tag{12.57}$$

也就是精确解的模型下降量，减去误差。

两种接受条件 区分两种条件。“不劣于当前点”即 $m(\tilde{\boldsymbol{z}}) \le m(\boldsymbol{x}_J)$，它能维持单调性，但太弱：$\tilde{\boldsymbol{z}} = \boldsymbol{x}_J$ 也能通过，一点进展都没有。

支持长期进展的是相对精度：取 $0 \le \eta < 1$，要求

$$m(\tilde{\boldsymbol{z}}) - m(\boldsymbol{z}^{\star}) \le \eta\big(m(\boldsymbol{x}_J) - m(\boldsymbol{z}^{\star})\big). \tag{12.58}$$

由式 (12.57)，这样的近似解保留精确解模型下降量的 $(1-\eta)$ 倍。精确解的所有保底下降界乘以 $(1-\eta)$ 仍然成立，收敛速率只差一个常数因子。

怎样测量误差 $m(\boldsymbol{z}^\star)$ 通常不知道，需要可计算的上界。设子问题是正定二次函数，$\boldsymbol{P}$ 是对称正定矩阵，且 $\boldsymbol{P} \succeq \sigma \boldsymbol{I}$，$\sigma > 0$：

$$m(\boldsymbol{z}) = \frac{1}{2}\boldsymbol{z}^\top \boldsymbol{P}\boldsymbol{z} - \boldsymbol{q}^\top \boldsymbol{z}.$$

梯度残差 $\boldsymbol{s} = \boldsymbol{P}\tilde{\boldsymbol{z}} - \boldsymbol{q}$ 是可以计算的。由 $\boldsymbol{z}^\star = \boldsymbol{P}^{-1}\boldsymbol{q}$，得 $\tilde{\boldsymbol{z}} - \boldsymbol{z}^\star = \boldsymbol{P}^{-1}\boldsymbol{s}$。二次函数在最小点附近精确地展开为

$$m(\tilde{\boldsymbol{z}}) - m(\boldsymbol{z}^\star) = \frac{1}{2}(\tilde{\boldsymbol{z}} - \boldsymbol{z}^\star)^\top \boldsymbol{P}(\tilde{\boldsymbol{z}} - \boldsymbol{z}^\star) = \frac{1}{2}\boldsymbol{s}^\top \boldsymbol{P}^{-1}\boldsymbol{s}.$$

再由 $\boldsymbol{P}^{-1}$ 的最大特征值不超过 $1/\sigma$，得到

$$m(\tilde{\boldsymbol{z}}) - m(\boldsymbol{z}^\star) \le \frac{\|\boldsymbol{s}\|_2^2}{2\sigma}. \tag{12.59}$$

例中 $x_2 = 4$ 时，条件函数是 $z^2 + 4z + 16$，所以 $P = 2$，$q = -4$，$\sigma = 2$。取 $\tilde{z} = -1.9$，残差 $s = 2(-1.9) + 4 = 0.2$，误差确实是 $(-1.9 + 2)^2 = 0.01$，而界 $s^2/(2\sigma) = 0.04/4 = 0.01$ 恰好取到。

固定绝对误差的精度限制 若每步都有相同的绝对误差 ε，长期结果就有下限。设无误差时有收缩 $E^{(t+1)} \le (1-\rho)E^{(t)}$，$0 < \rho < 1$，这里 $E^{(t)}$ 是目标差或其期望。由式 (12.57)，有误差时变成

$$E^{(t+1)} \le (1-\rho)E^{(t)} + \varepsilon.$$

展开这个递推，并对等比级数求和，得到

$$E^{(T)} \le (1-\rho)^T E^{(0)} + \frac{\varepsilon}{\rho}. \tag{12.60}$$

第一项趋于零，第二项不会消失，算法最终停在一个与 ε/ρ 同量级的平台上。图 12.24的黄线就是这个平台，紫线用相对精度 (12.58)的同类要求，一直下降，只是比精确解慢一些。

12.1 分块问题
12.2 块坐标下降（BCD）
12.3 局部近似更新
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.7.1 串行与并行
12.7.2 子问题的求解精度
12.7.3 收敛保证
12.7.4 计算成本
12.8 本章小结

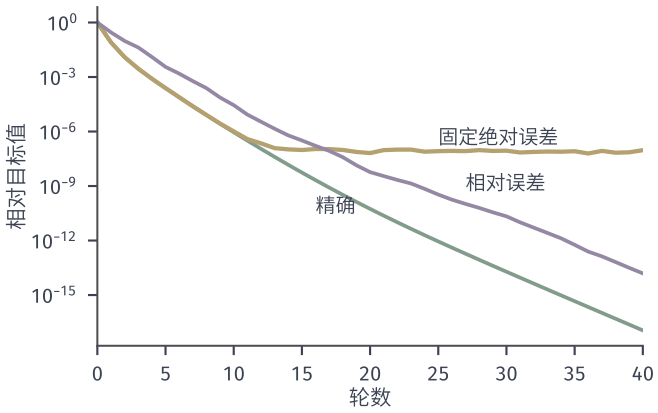


图 12.24 块子问题误差的影响。$n = 40$ 的正定二次目标，每块 8 个变量，循环更新。绿线是精确块解；黄线的每次块解有固定的残差范数 10^{-3}，目标值停在平台上；紫线的残差范数取当前偏梯度范数的一半，仍线性收敛。

内层成本与解的复用 相对精度也有成本。把一块解到较高精度需要更多内层迭代，而上一轮的块解是内层求解的好起点，这称为热启动；固定曲率时，矩阵分解还能重复使用。接受标准定得太严，一步就要做很多无用的内层迭代；定得太松，外层要多走好多轮。两者的总和才是要比较的量。

12.7.3 收敛保证

三个不同的问题 “算法收敛”可以指三件不同的事，由弱到强依次是：目标值序列收敛；迭代点的聚点是驻点；整个迭代点序列收敛到一点。下面分别看各需要什么条件。

目标值收敛 只要每步不增且目标有下界，目标值序列就收敛。精确块更新由引理 12.2满足单调性，BCGD 由式 (12.21)满足，BSUM 由式 (12.44)满足，BPG 由式 (12.49)满足。这个结论很弱，它不说明目标值收敛到哪里，更不说明点收敛。

聚点驻定 聚点的性质需要逐条检查四件事：块访问，即每一块都被反复更新；解的选择，即子问题的解有确定的规则，这里要求唯一；水平集条件，使迭代有聚点；以及分块的最优性条件能否合成整体驻点条件。

下面给出循环规则下的结论。设 $\boldsymbol{C}$ 是闭凸集的乘积，F 在 $\boldsymbol{C}$ 上连续。

定理 12.10 循环 BSUM 的聚点 设 $\boldsymbol{x}^{(0)} \in \boldsymbol{C}$，下水平集

$$\boldsymbol{S} = \{\boldsymbol{x} \in \boldsymbol{C} : F(\boldsymbol{x}) \le F(\boldsymbol{x}^{(0)})\} \tag{12.61}$$

是紧集。设每个块的 u_J 满足定义 12.6，且对每个 $\boldsymbol{y} \in \boldsymbol{S}$，$u_J(\cdot;\boldsymbol{y})$ 在 $\boldsymbol{C}_J$ 上有唯一的最小点。按固定顺序循环更新各块，则每轮开始时的点列 $\{\boldsymbol{x}^{(t)}\}$ 有聚点，并且每个聚点 $\bar{\boldsymbol{x}}$ 满足

$$\bar{\boldsymbol{x}}_J = \arg\min_{\boldsymbol{z} \in \boldsymbol{C}_J} u_J(\boldsymbol{z};\bar{\boldsymbol{x}}) \quad \text{对每个块 } J, \tag{12.62}$$

$$F'(\bar{\boldsymbol{x}};\boldsymbol{U}_J\boldsymbol{d}) \ge 0 \quad \text{对每个块 } J \text{ 和满足 } \bar{\boldsymbol{x}}_J + \boldsymbol{d} \in \boldsymbol{C}_J \text{ 的 } \boldsymbol{d}. \tag{12.63}$$

证明 记 $M_J(\boldsymbol{y})$ 为只把 $\boldsymbol{y}$ 的块 J 替换成 $u_J(\cdot;\boldsymbol{y})$ 的最小点得到的点。由下降链 (12.44)，M_J 把 $\boldsymbol{S}$ 映入 $\boldsymbol{S}$，迭代始终留在 $\boldsymbol{S}$ 中。$\boldsymbol{S}$ 紧，所以聚点存在，$F(\boldsymbol{x}^{(t)})$ 单调有界而收敛到某个 $\bar{F}$，由连续性，每个聚点满足 $F(\bar{\boldsymbol{x}}) = \bar{F}$。

先证 M_J 在 $\boldsymbol{S}$ 上连续。设 $\boldsymbol{y}^{(k)} \to \boldsymbol{y}$，$\boldsymbol{y}^{(k)} \in \boldsymbol{S}$，任取 $M_J(\boldsymbol{y}^{(k)})$ 的一个收敛子列，极限 $\bar{\boldsymbol{z}}$ 在 $\boldsymbol{S}$ 中，且只在块 J 上与 $\boldsymbol{y}$ 不同。对任意 $\boldsymbol{w} \in \boldsymbol{C}_J$，有

$$u_J\big(M_J(\boldsymbol{y}^{(k)})_J;\boldsymbol{y}^{(k)}\big) \le u_J(\boldsymbol{w};\boldsymbol{y}^{(k)}).$$

令 $k \to \infty$，由 u_J 的连续性，$\bar{\boldsymbol{z}}_J$ 是 $u_J(\cdot;\boldsymbol{y})$ 的最小点，由唯一性，$\bar{\boldsymbol{z}} = M_J(\boldsymbol{y})$。紧集中的序列每个收敛子列的极限都相同，所以 $M_J(\boldsymbol{y}^{(k)}) \to M_J(\boldsymbol{y})$。

再设子列 $\boldsymbol{x}^{(t_j)} \to \bar{\boldsymbol{x}}$，块的顺序是 $J_1,\dots,J_B$。令 $\boldsymbol{z}^{j,0} = \boldsymbol{x}^{(t_j)}$，$\boldsymbol{z}^{j,k} = M_{J_k}(\boldsymbol{z}^{j,k-1})$。下面对 k 归纳证明 $\boldsymbol{z}^{j,k} \to \bar{\boldsymbol{x}}$（$j \to \infty$）。设 $\boldsymbol{z}^{j,k-1} \to \bar{\boldsymbol{x}}$，由 M_{J_k} 的连续性，$\boldsymbol{z}^{j,k}$ 收敛到点

$$\bar{\boldsymbol{w}} = M_{J_k}(\bar{\boldsymbol{x}}).$$

由单调性，

$$F(\boldsymbol{x}^{(t_j+1)}) \le F(\boldsymbol{z}^{j,k}) \le F(\boldsymbol{x}^{(t_j)}),$$

两端都趋于 $\bar{F}$，所以 $F(\bar{\boldsymbol{w}}) = \bar{F}$。再由下降链，

$$\bar{F} = F(\bar{\boldsymbol{w}}) \le u_{J_k}(\bar{\boldsymbol{w}}_{J_k};\bar{\boldsymbol{x}}) \le u_{J_k}(\bar{\boldsymbol{x}}_{J_k};\bar{\boldsymbol{x}}) = F(\bar{\boldsymbol{x}}) = \bar{F}.$$

这表明 $\bar{\boldsymbol{x}}_{J_k}$ 也是 $u_{J_k}(\cdot;\bar{\boldsymbol{x}})$ 的最小点。由唯一性，$\bar{\boldsymbol{w}} = \bar{\boldsymbol{x}}$，归纳完成，并且式 (12.62)对每个 J_k 成立。

> 最后，$\bar{\boldsymbol{x}}_J$ 最小化 $u_J(\cdot;\bar{\boldsymbol{x}})$，$\boldsymbol{C}_J$ 是凸集，所以沿任何可行方向的方向导数非负。由一阶条件 (12.43)，这就是式 (12.63)。 ■

取 u_J 为条件函数，定理就覆盖了精确 BCD。定理中的条件各有用处：紧性让聚点存在；唯一性决定了不动点论证中的 $\bar{\boldsymbol{w}} = \bar{\boldsymbol{x}}$；循环访问保证每个块都被访问到。“每隔固定步数每块至少访问一次”的规则也能用同样的论证。

唯一性去掉会怎样 最小点不唯一时，聚点可以不是驻点。一个经典的三变量例子是

$$f(\boldsymbol{x}) = -(x_1x_2 + x_2x_3 + x_3x_1) + \sum_{i=1}^{3}(|x_i| - 1)_+^2,$$

其中 $(s)_+ = \max\{s, 0\}$。固定其余两个变量，令和为 $s \neq 0$ 时，x_1 的最小点唯一，是 $\operatorname{sign}(s)(1 + |s|/2)$；$s = 0$ 时，$[-1, 1]$ 上每一点都是最小点。

从下面的起点出发循环更新，$\epsilon > 0$：

$$\boldsymbol{x}^{(0)} = \Big(-1 - \epsilon,\ 1 + \frac{\epsilon}{2},\ -1 - \frac{\epsilon}{4}\Big).$$

三步之后的三个坐标依次是

$$x_1 = 1 + \frac{\epsilon}{8}, \qquad x_2 = -1 - \frac{\epsilon}{16}, \qquad x_3 = 1 + \frac{\epsilon}{32}.$$

每次偏离 ± 1 的量缩小到一半，符号不断翻转，迭代点沿立方体的六个顶点循环，聚点是这些顶点。

顶点不是驻点，比如 $(1, 1, -1)$ 处 $\partial_3 f = -2$，$\partial_1 f = \partial_2 f = 0$。问题正出在极限处 $s = 0$：条件子问题的最小点不再唯一，M_J 不再连续，定理的论证在这里断开。这个例子的目标也没有下界，这里关心的是解的选择造成的现象，水平集条件并不是它失效的主因。

合成整体驻点 式 (12.63)只说沿块方向的方向导数非负。能否合成整体驻点，要看方向导数在块间是否可加。F 可微时，方向导数按块相加：

$$F'(\bar{\boldsymbol{x}}; \boldsymbol{d}) = \sum_J \langle \nabla_J F(\bar{\boldsymbol{x}}), \boldsymbol{d}_J \rangle,$$

每一项非负，和也非负，这就是闭凸可行域上的驻点条件。

$F = f + \sum_J g_J$ 且 g_J 凸时，方向导数同样按块相加，结论也成立；F 凸时由此得到全局最优。例 (12.5)的方向导数不能按块分开，这一步失败。

整列收敛 聚点驻定仍然允许序列在几个驻点之间徘徊。整列收敛到一点需要更强的条件，典型的是强凸性。若 F 是 μ 强凸的且 $F(\boldsymbol{x}^{(t)}) \to F^\star$，则由

$$\frac{\mu}{2}\|\boldsymbol{x}^{(t)} - \boldsymbol{x}^\star\|_2^2 \le F(\boldsymbol{x}^{(t)}) - F^\star$$

得到 $\boldsymbol{x}^{(t)} \to \boldsymbol{x}^\star$。非强凸时需要借助目标在解附近的增长性质，这超出本章范围。

随机 BCGD 的有限步界 上面的结论都是渐近的，下面给出有限步的结果。这里考虑独立均匀选块、使用精确偏梯度的 BCGD，分析的关键仍是单步的平均下降。

定理 12.11 随机 BCGD 的收敛率 设 $f:\mathbb{R}^n \to \mathbb{R}$ 有下界 $f^\star$，关于每一块是 L_J 光滑的，记 $L_{\max} = \max_J L_J$。每步与历史独立地均匀抽取一块，按式 (12.20)更新。则有

$$\mathbb{E}\big[f(\boldsymbol{x}^{(t+1)}) \mid \boldsymbol{x}^{(t)}\big] \le f(\boldsymbol{x}^{(t)}) - \frac{1}{2BL_{\max}}\|\nabla f(\boldsymbol{x}^{(t)})\|_2^2, \tag{12.64}$$

$$\min_{0\le t<T} \mathbb{E}\|\nabla f(\boldsymbol{x}^{(t)})\|_2^2 \le \frac{2BL_{\max}\big(f(\boldsymbol{x}^{(0)}) - f^\star\big)}{T}. \tag{12.65}$$

若 f 还是 μ 强凸的，则

$$\mathbb{E} f(\boldsymbol{x}^{(T)}) - f^\star \le \Big(1 - \frac{\mu}{BL_{\max}}\Big)^T \big(f(\boldsymbol{x}^{(0)}) - f^\star\big). \tag{12.66}$$

证明 抽到块 J 的概率是 $1/B$，由式 (12.21)，此时下降量至少是 $\|\nabla_J f\|_2^2/(2L_J)$。对 B 个块取平均，并用 $L_J \le L_{\max}$，得到

$$\mathbb{E}\big[f(\boldsymbol{x}^{(t+1)}) \mid \boldsymbol{x}^{(t)}\big] \le f(\boldsymbol{x}^{(t)}) - \frac{1}{2BL_{\max}}\sum_J \|\nabla_J f(\boldsymbol{x}^{(t)})\|_2^2.$$

各块的下标互不重叠且并起来是全部下标，所以

$$\sum_J \|\nabla_J f\|_2^2 = \|\nabla f\|_2^2,$$

这就是式 (12.64)。

对式 (12.64)取全期望，并对 $t = 0, \dots, T-1$ 求和，左右两边的目标值相消，得到

$$\frac{1}{2BL_{\max}}\sum_{t=0}^{T-1} \mathbb{E}\|\nabla f(\boldsymbol{x}^{(t)})\|_2^2 \le f(\boldsymbol{x}^{(0)}) - \mathbb{E} f(\boldsymbol{x}^{(T)}) \le f(\boldsymbol{x}^{(0)}) - f^\star.$$

12.1 分块问题
12.2 块坐标下降（BCD）
12.3 局部近似更新
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.7.1 串行与并行
12.7.2 子问题的求解精度
12.7.3 收敛保证
12.7.4 计算成本
12.8 本章小结

最小值不超过平均值，移项即得式 (12.65)。

强凸时，把强凸下界对 $\boldsymbol{y}$ 取最小：

$$
\begin{aligned}
f^\star &\geq \min_{\boldsymbol{y}} \Big\{ f(\boldsymbol{x}) + \langle \nabla f(\boldsymbol{x}), \boldsymbol{y}-\boldsymbol{x} \rangle + \frac{\mu}{2}\|\boldsymbol{y}-\boldsymbol{x}\|_2^2 \Big\} \\
&= f(\boldsymbol{x}) - \frac{1}{2\mu}\|\nabla f(\boldsymbol{x})\|_2^2,
\end{aligned}
$$

也就是

$$
\|\nabla f(\boldsymbol{x})\|_2^2 \geq 2\mu\big(f(\boldsymbol{x}) - f^\star\big).
$$

把它代入式 (12.64)，两边减去 $f^\star$，得到

$$
\mathbb{E}\big[f(\boldsymbol{x}^{(t+1)}) - f^\star \mid \boldsymbol{x}^{(t)}\big] \leq \Big(1 - \frac{\mu}{BL_{\max}}\Big)\big(f(\boldsymbol{x}^{(t)}) - f^\star\big).
$$

取全期望并反复使用即得式 (12.66)。 ■

例中 $B=2$，$L_{\max}=2$，$\mu=1$，因子是 $\frac{3}{4}$。从 $f=37$ 出发一步后，定理的上界是 27.75，实际的平均值是 9.375：定理只用了最坏的块光滑常数，实际情况好得多。

B 次更新的成本约等于一次全梯度，这时因子约为 $1-\mu/L_{\max}$。与第 6章梯度下降每步的 $1-\mu/L$ 相比，$L_{\max}$ 越小于 L，块方法越有优势[1]。式 (12.23)中的 $L_j \leq L$ 保证了这个比较不会反过来。

加速方法另当别论 定理 12.11的论证依赖于每步的单调下降。APCG 的 $F(\boldsymbol{x}^{(t)})$ 不是单调的，这里的论证用不上，定理 12.4的结论要靠辅助序列的递推才能得到。

12.7.4 计算成本

一次更新的读取量 最后回到开头的问题：计算真的省了吗？以稠密的 $\boldsymbol{A}\in\mathbb{R}^{N\times n}$ 为例，比较三种操作的运算量（只数乘法）。一次单坐标更新要读 $\boldsymbol{a}_j^\top \boldsymbol{r}$ 和更新 $\boldsymbol{r}$，各需 N 次；一次完整遍历 n 个坐标，一次全梯度要算 $\boldsymbol{A}\boldsymbol{x}$ 和 $\boldsymbol{A}^\top\boldsymbol{r}$，结果如下表。

操作	稠密 $\boldsymbol{A}$	稀疏 $\boldsymbol{A}$
一次单坐标更新	$2N$	$2\,\mathrm{nnz}(\boldsymbol{a}_j)$
一轮（n 次更新）	$2Nn$	$2\,\mathrm{nnz}(\boldsymbol{A})$
一次全梯度	$2Nn$	$2\,\mathrm{nnz}(\boldsymbol{A})$

12.1 分块问题
12.2 块坐标下降（BCD）
12.3 局部近似更新
12.4 交替极小化
12.5 块上界最小化（BSUM）
12.6 块邻近梯度（BPG）
12.7 实现与收敛
12.8 本章小结

由此可知，维护残差之后，一轮坐标更新和一次全梯度的成本相同。若没有维护残差，每次更新都重算 $\boldsymbol{Ax}$，一轮的成本就变成全梯度的 n 倍，优势全失。

例中 $\boldsymbol{A}$ 每列两个非零元，一次更新要 4 次乘法，一轮 8 次，一次全梯度也是 8 次。花同样的计算，一轮循环坐标下降把目标值乘以 $\frac{1}{16}$，最优固定步长的梯度下降每步只乘以 $\frac{1}{4}$（$\kappa = 3$，由第 6章的结论，$((\kappa-1)/(\kappa+1))^2 = \frac{1}{4}$）。

完整的成本清单 比较几种方法要用同一个目标和同一个精度要求，并把下表中的所有项计入，只算迭代次数或只算单步代价都会得出错误的结论。

项目	何时发生	怎样减少
选块	贪心规则要所有块的偏梯度	增量维护、优先队列
曲率形成	块 Newton、L_J 的计算	只算一次、用上界估计
内层求解	精确块解、块 Newton、$\boldsymbol{U}$ 的方程	复用分解、热启动
外推	APCG 的全向量组合	用两个基向量表示
内存	残差、偏梯度、分解因子	只保留必要的中间量
同步	并行时的等待与写冲突	块之间数据不重叠

检查“较少的块更新是否真正减少总工作量”时，要回到图 12.3(b) 的做法：把横轴换成总运算量。块大一倍、轮数减半不一定划算，贪心规则迭代次数少也不一定划算；只有总运算量下降，才算真正的进步。

12.8 本章小结

本章从一个朴素的想法出发：变量合在一起难处理，拆开之后每一部分都便宜。全章回答了开头提出的两个问题。

第一，只动一部分变量能否推进完整目标。可以，但要看更新的类型。精确块更新靠“当前点本身是候选”保证下降，BCGD 和 BPG 靠块上界保证下降，这些都可以统一到 BSUM 的下降链：上界不低于目标，当前点相等，最小化上界不会让目标上升。块 Newton 法和 APCG 不在这条链上，前者要靠线搜索或信赖域，后者靠辅助序列。

下面的表把四类更新放在一起。

更新	子问题	主要条件
精确 BCD、ALS	条件子问题	最小点存在，选解规则；ALS 要求因子满列秩或用伪逆
BCGD	二次上界	块光滑常数 L_J
BPG	二次上界加 g_J	g_J 按块可分，邻近映射可算
APCG	外推点的块邻近模型	f 凸，块光滑，解存在，均匀抽块，精确块求解

下降不等于解出问题。逐块最优、驻点、全局最优是三个不同的层次。光滑或可分时逐块最优能合成驻点，联合凸时驻点才是全局最优；不可分的非光滑项会让坐标下降停在非驻点，分别凸的矩阵分解可能停在鞍点。循环规则下，聚点是逐块最优点需要紧水平集和子问题解唯一；独立均匀抽块的 BCGD 有有限步的梯度界，强凸时有线性收缩，都是对期望而言。

选块规则和块内更新可以自由组合，但保证要重新核对。随机选的是更新位置，不需要也不应当做逆概率校正；贪心规则的便宜程度取决于偏梯度能否增量维护；并行更新要用覆盖同时变化的联合上界，步长通常按同时更新的块数缩小。

第二，省下的计算会不会被更多的迭代抵消。这要落到总工作量上比较。维护残差后，一轮坐标更新和一次全梯度成本相同，这才让坐标方法在强耦合较少、块常数远小于全局常数时取得优势；块大小、选块、内层精度、外推和同步的成本都要算进去。

本章的偏梯度都是精确的。当目标是大量项的和、每次只读其中一部分时，方向本身带有误差，这是下一部分研究的问题。

第五部分

随机优化

Stochastic Optimization

阅读指引

前面的方法都假定能读到准确的目标值和梯度。实际问题中常常只能读到一部分数据上的梯度、带噪声的函数值，甚至只知道评价一次很昂贵。本部分按可取得的信息和更新方式划分四章。

第 13章使用随机梯度：每步只读取部分目标项，用较低的单步代价换来有噪声的方向，再通过步长、方差控制、动量和自适应缩放控制误差。第 14章只能读取函数值，用扰动和差分构造局部方向。第 15章放弃局部方向，通过随机提议、群体变异和历史记忆探索解空间。第 16章面向每次评价都昂贵的黑箱问题，用概率模型总结已有观测，再决定下一个评价点。

“随机”在这四章里含义不同：可能是算法抽样的随机，可能是函数值中的噪声，也可能只是用概率描述我们对未知函数的了解。各章在开头分别说明，不混用。

13.1 随机目标与梯度估计
13.1.1 有限和目标
13.1.2 期望目标
13.1.3 条件无偏与读数误差
13.1.4 循环读取与随机重排
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

第 13 章

随机梯度方法

要拟合一百万条观测，目标是每条观测上误差的平均。梯度下降每走一步，都要把一百万条观测读一遍，只为知道下山的方向。可是这个方向本身只是一个平均值，而估计平均值并不需要读完全部数据：问几个人，就能大致知道全校的平均身高。于是有了本章的想法：每一步只读一小部分目标项，用它代替完整梯度。

这个想法马上带来几个问题。只读一项得到的方向可能是错的，甚至指向上山，那么算法凭什么收敛？读数的抖动在最优点附近也不停止，迭代点最后会停在哪里，步长应该怎样选？既然噪声是麻烦，能不能设法把它压下去，压下去又要花多少代价？

本章按这样的路线回答。先固定要最小化的目标，说清一个随机向量什么时候算作当前梯度的估计，再把它代入更新，建立有限步的误差界，并比较返回哪个点。然后研究怎样减小估计的误差。此后转向另一类做法：不改变读取的对象，而改变读数被使用的方式，包括累积历史方向、按坐标调整尺度和事先处理梯度。最后回到原目标，比较误差和总计算量。

全章用同一个三项一元二次目标做例子。它小到可以手算，每一项的梯度又足够不同，读一项和读全部的差别看得很清楚。

13.1 随机目标与梯度估计

只读部分信息时，手里得到的向量和当前点的真梯度是什么关系？回答它需要先说清要最小化的是哪个目标，再说清“随机”来自哪里，最后给出“这个读数可以当作梯度用”的准确含义。读取的顺序也会改变这一含义，放在本节最后讨论。

13.1.1 有限和目标

先看最常见的情形：数据已经固定，目标是 N 项的平均。

目标与完整梯度　设 $f_i : \mathbb{R}^n \to \mathbb{R}$，$i = 1, \dots, N$，都可微。有限和目标（finite-sum objective）是

$$f(\boldsymbol{x}) = \frac{1}{N} \sum_{i=1}^{N} f_i(\boldsymbol{x}). \tag{13.1}$$

求导对有限和可以逐项进行，所以完整梯度是各项梯度的平均：

$$\nabla f(\boldsymbol{x}) = \frac{1}{N} \sum_{i=1}^{N} \nabla f_i(\boldsymbol{x}). \tag{13.2}$$

要得到它，必须把 N 项都计算一遍。本章把计算一项梯度称为一次读取，完整梯度的代价是 N 次读取。

均匀抽取一项　现在换一种获取信息的方式：在 $\{1, \dots, N\}$ 中均匀抽一个下标 i，只计算 $\nabla f_i(\boldsymbol{x})$。每个下标的概率都是 $1/N$，因此对这次抽样求平均，得到

$$\mathbb{E}_i[\nabla f_i(\boldsymbol{x})] = \sum_{i=1}^{N} \frac{1}{N} \nabla f_i(\boldsymbol{x}) = \nabla f(\boldsymbol{x}). \tag{13.3}$$

目标函数并没有变，变的只是当前拿到的信息：从全部 N 项变成其中一项。

这就像估计全校的平均身高：不必量遍每个人，随机问一个人，他的身高在平均意义上就是全校的平均。学生对应目标项，身高对应该项的梯度，全校平均对应完整梯度。这个类比有两处失效。身高不随时间改变，而 $\nabla f_i(\boldsymbol{x})$ 随 $\boldsymbol{x}$ 改变，每走一步都要重新估计。另外，估计身高只要结果，估计梯度还要照着它走路，走错的后果会带到下一步。

贯穿全章的三项目标　取一元、三项的目标，每项是一条抛物线：

$$f_i(x) = \frac{a_i}{2}(x - b_i)^2, \qquad (a_1, a_2, a_3) = (1, 2, 3), \qquad (b_1, b_2, b_3) = (-3, 0, 3). \tag{13.4}$$

三项写出来是

$$f_1(x) = \frac{1}{2}(x + 3)^2, \qquad f_2(x) = x^2, \qquad f_3(x) = \frac{3}{2}(x - 3)^2.$$

把三项相加再除以 3。二次项系数是 $\frac{1}{6} + \frac{1}{3} + \frac{1}{2} = 1$，一次项系数是 $1 + 0 - 3 = -2$，常数项是 $\frac{3}{2} + 0 + \frac{9}{2} = 6$，所以

$$f(x) = x^2 - 2x + 6 = (x - 1)^2 + 5. \tag{13.5}$$

于是最小点和最优值是

$$x^\star = 1, \qquad f^\star = 5.$$

各项的梯度 $f_i'(x) = a_i(x - b_i)$ 与完整梯度是

$$f_1'(x) = x + 3, \qquad f_2'(x) = 2x, \qquad f_3'(x) = 3x - 9, \qquad f'(x) = 2x - 2. \tag{13.6}$$

这里 f 的曲率是 2，所以 $L = \mu = 2$；各项自身的曲率是 $L_i = a_i$，最大为 3。

在 $x = 2$ 处，三项的读数和完整梯度是

$$f_1'(2) = 5, \qquad f_2'(2) = 4, \qquad f_3'(2) = -3, \qquad f'(2) = 2.$$

第三项的读数是负的，说明它主张向右走，而完整梯度要求向左走。最优点 $x^\star = 1$ 恰在左边，听第三项的话就走反了。在最优点，三项读数为 $(4, 2, -6)$，它们的和是零，但没有一项是零。完整梯度已经停下，单项读数并没有停下。这两个现象会贯穿全章。

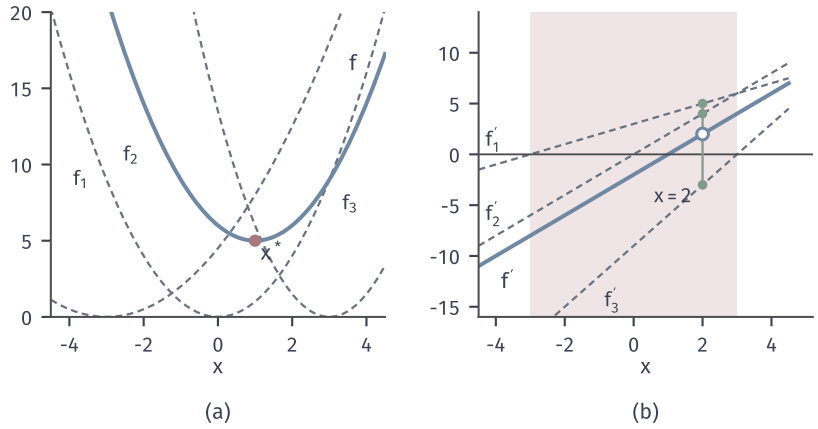


图 13.1　三项目标 (13.4)。(a) 虚线是三条单项抛物线 f_1, f_2, f_3，实线是它们的平均 f，红点是 f 的最小点 $x^\star = 1$，各项的最小点都不在这里。(b) 虚线是单项导数，实线是 f'。红底区间 $[-3, 3]$ 内三项导数不同号；区间外三项同号，都指向区间。竖线段标出 $x = 2$ 处的三个读数 $5, 4, -3$，空心点是它们的平均 2。

图 13.1(b) 给出了分歧发生的位置。三条单项导数的零点是 $-3, 0, 3$，在这三个数之外，三项一致地指向同一边，读哪一项方向都对。进入 $[-3, 3]$ 后各项开始争执。所以离解还远时，单项读数和完整梯度方向相同；离解越近，分歧越明显。

归一化、正则项与读取成本　式 (13.1)里的 $1/N$ 不是可有可无的约定。若目标写成不除以 N 的总和，最小点不变，但梯度和光滑常数都放大 N 倍，

13.1 随机目标与梯度估计
13.1.1 有限和目标
13.1.2 期望目标
13.1.3 条件无偏与读数误差
13.1.4 循环读取与随机重排
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

同一个数值的步长含义完全不同。本章一律使用平均的写法，步长 α 可以脱离 N 来讨论。

许多目标还带确定的正则项 r，例如 $r(\boldsymbol{x}) = \frac{\gamma}{2}\|\boldsymbol{x}\|_2^2$：

$$f(\boldsymbol{x}) = \frac{1}{N}\sum_{i=1}^{N} f_i(\boldsymbol{x}) + r(\boldsymbol{x}). \tag{13.7}$$

r 不依赖数据项，它的梯度每步都能精确算出，无需抽样。读数应写成 $\nabla f_i(\boldsymbol{x}) + \nabla r(\boldsymbol{x})$。如果把 r 放进每一项，写成 $f_i + r$，结果相同；要避免的是只在抽到某些项时才加入 r，或把系数随 N 改变而不作说明。

计数时要分清两种成本：一次读取是对单项的梯度计算，一次更新是对 $\boldsymbol{x}$ 的修改。完整梯度下降每次更新 N 次读取，只读一项时每次更新一次读取。比较算法时，本章以读取次数为主要的计量单位。

13.1.2 期望目标

很多问题中项数不是固定的 N。观测可以源源不断地取得，或者目标本来就是在某个分布上的平均。

从有限平均到期望 设 $\boldsymbol{\xi}$ 是可以抽样的随机变量，对每个 $\boldsymbol{\xi}$ 的取值有函数 $\phi(\boldsymbol{x};\boldsymbol{\xi})$。**期望目标**（expected objective）是

$$f(\boldsymbol{x}) = \mathbb{E}_{\boldsymbol{\xi}}[\phi(\boldsymbol{x};\boldsymbol{\xi})]. \tag{13.8}$$

有限和是特例：取 $\boldsymbol{\xi}$ 为均匀分布的下标 i，$\phi(\boldsymbol{x};i) = f_i(\boldsymbol{x})$。三项目标正是这样，$f$ 是三点分布上的期望。

一般情况下无法把所有取值列出来，也无法求出 f，却能抽样。这样就有两种不同的做法。

一种是直接优化期望：每一步抽一个新样本，把它的梯度用于更新。每个样本只用一次，读取总数等于样本总数，要最小化的始终是式 (13.8)。另一种是先固定一批样本：一次抽定 $\boldsymbol{\xi}_1, \dots, \boldsymbol{\xi}_N$，得到

$$f_N(\boldsymbol{x}) = \frac{1}{N}\sum_{i=1}^{N} \phi(\boldsymbol{x};\boldsymbol{\xi}_i),$$

然后把 f_N 当作有限和目标反复读取。这时算法解的是 f_N，它的解一般不是 f 的解。

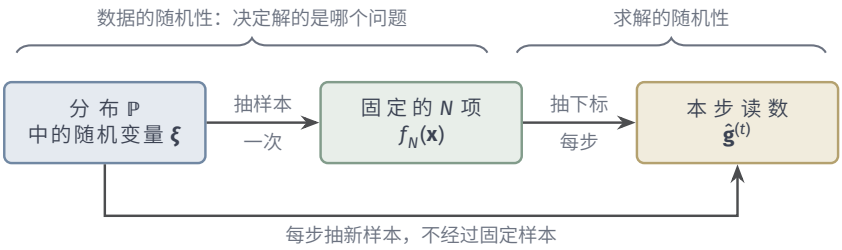


图 13.2　两层随机性。上方路线先抽定 N 个样本，得到确定的有限和 f_N，之后每步只对下标抽样。下方路线不经过固定样本，每步直接抽新样本。第一层随机性决定了算法解的是哪个问题，第二层只影响算法解这个问题的过程。

图 13.2区分了这两层随机性。举一个具体的例子：取 $\phi(x;\xi)=\frac{1}{2}(x-\xi)^2$，$\xi$ 的均值为 1。期望目标的最小点是 1，而 f_N 的最小点是样本均值 $\bar{\xi}_N$，它随样本变化。无论优化做得多准，都只能精确得到 $\bar{\xi}_N$；$\bar{\xi}_N$ 与 1 的差属于数据造成的统计误差。本章固定目标，只研究优化误差。统计误差的大小可参考卷八第 4 章“有限样本的误差上界”。

逐样本求导的条件　随机梯度要求 $\nabla\phi(\boldsymbol{x};\boldsymbol{\xi})$ 的期望等于 $\nabla f(\boldsymbol{x})$，也就是导数和期望可以交换。有限和中这一步只是有限项相加，期望的情形需要条件。

引理 13.1　逐样本求导　设 $\boldsymbol{x}$ 有开球邻域 $\boldsymbol{U}$，$\phi(\boldsymbol{x};\boldsymbol{\xi})$ 可积。若几乎所有 $\boldsymbol{\xi}$ 使 $\phi(\cdot;\boldsymbol{\xi})$ 在 $\boldsymbol{U}$ 上可微，且存在可积函数 $M(\boldsymbol{\xi})$，使

$$\|\nabla\phi(\boldsymbol{y};\boldsymbol{\xi})\|_2 \le M(\boldsymbol{\xi}), \qquad \boldsymbol{y}\in\boldsymbol{U}, \tag{13.9}$$

则 f 在 $\boldsymbol{x}$ 处可微，并且

$$\nabla f(\boldsymbol{x}) = \mathbb{E}_{\xi}[\nabla\phi(\boldsymbol{x};\boldsymbol{\xi})]. \tag{13.10}$$

证明　记 $\boldsymbol{v}(\boldsymbol{\xi})=\nabla\phi(\boldsymbol{x};\boldsymbol{\xi})$。由式 (13.9)，$\boldsymbol{v}$ 可积。取 $\boldsymbol{h}^{(k)}\to\mathbf{0}$，$\boldsymbol{h}^{(k)}\neq\mathbf{0}$，且 $\boldsymbol{x}+\boldsymbol{h}^{(k)}\in\boldsymbol{U}$，令

$$R_k(\boldsymbol{\xi}) = \frac{\phi(\boldsymbol{x}+\boldsymbol{h}^{(k)};\boldsymbol{\xi}) - \phi(\boldsymbol{x};\boldsymbol{\xi}) - \langle \boldsymbol{v}(\boldsymbol{\xi}), \boldsymbol{h}^{(k)}\rangle}{\|\boldsymbol{h}^{(k)}\|_2}.$$

对几乎所有 $\boldsymbol{\xi}$，由可微性有 $R_k(\boldsymbol{\xi})\to 0$。沿线段使用中值定理，并由式 (13.9)，得到

$$|R_k(\boldsymbol{\xi})| \le 2M(\boldsymbol{\xi}).$$

这说明 $\phi(\boldsymbol{x}+\boldsymbol{h}^{(k)};\cdot)$ 也可积，f 在这些点有定义。

13.1 随机目标与梯度估计
13.1.1 有限和目标
13.1.2 期望目标
13.1.3 条件无偏与读数误差
13.1.4 循环读取与随机重排
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

控制收敛定理给出 $\mathbb{E}[R_k]\to 0$，定理的条件和证明见卷四第 6 章“积分”。序列 $\boldsymbol{h}^{(k)}$ 是任取的，所以这正是 f 在 $\boldsymbol{x}$ 处以 $\mathbb{E}[\boldsymbol{v}]$ 为梯度可微的定义。 ■

条件 (13.9)去掉后结论可以错得很彻底。取 ξ 在 $(0,1)$ 上均匀，$\phi(x;\xi)$ 是示性函数：当 $\xi\le x$ 时取 1，否则取 0。对 $x\in(0,1)$，期望目标是 $f(x)=x$，导数处处为 1。但对每个固定的 ξ，除 $x=\xi$ 这一点外函数都是常数，逐样本导数是 0，平均之后还是 0。跳跃点带来的贡献被逐样本求导完全漏掉了。对照引理的条件，落在 $\boldsymbol{U}$ 内的 ξ 使 $\phi(\cdot;\xi)$ 在 $y=\xi$ 处不连续，“在整个邻域上可微”这一条不成立；只在 x 这一点几乎处处可微是不够的。

分布本身依赖 $\boldsymbol{x}$ 时，式 (13.10)不能直接用，因为抽样分布也在变。常用的处理是把随机性移到不依赖 $\boldsymbol{x}$ 的变量上（重参数化），或用分布密度的对数导数作权重（得分函数估计），可参考卷七第 14 章“随机采样与积分计算”。本章下文只讨论分布不依赖 $\boldsymbol{x}$ 的情形。

13.1.3 条件无偏与读数误差

式 (13.3)是对固定的 $\boldsymbol{x}$ 写的。迭代中 $\boldsymbol{x}^{(t)}$ 本身由前面的抽样决定，也是随机的。需要一个能处理“当前点已经随机地到了这里”的说法。

历史与条件期望　把第 t 步抽样之前已经发生的一切称为历史，记为 $\mathcal{F}^{(t)}$：初始点、前 t 次抽到的下标。给定历史，$\boldsymbol{x}^{(t)}$ 就是一个确定的点。条件期望 $\mathbb{E}[\cdot\mid\mathcal{F}^{(t)}]$ 可以这样理解：把过去冻结，只对第 t 步的新抽样求平均。

本章反复使用条件期望的两条规则。历史已知的量可以提到条件期望外面：

$$\mathbb{E}[\,\boldsymbol{u}^{\top}\boldsymbol{v}\mid\mathcal{F}^{(t)}]=\boldsymbol{u}^{\top}\mathbb{E}[\boldsymbol{v}\mid\mathcal{F}^{(t)}],\qquad \boldsymbol{u}\text{由}\mathcal{F}^{(t)}\text{确定}. \tag{13.11}$$

先对新抽样平均、再对历史平均，等于直接取总平均，即全期望公式：

$$\mathbb{E}\big[\mathbb{E}[X\mid\mathcal{F}^{(t)}]\big]=\mathbb{E}[X]. \tag{13.12}$$

这两条规则的一般表述和条件可参考卷七第 4 章“条件期望与条件分布”。

下面把读数记作 $\hat{\boldsymbol{g}}^{(t)}$，$\boldsymbol{g}^{(t)}=\nabla f(\boldsymbol{x}^{(t)})$ 仍表示真梯度。

定义 13.2　条件无偏　若随机向量 $\hat{\boldsymbol{g}}^{(t)}$ 满足

$$\mathbb{E}[\hat{\boldsymbol{g}}^{(t)}\mid\mathcal{F}^{(t)}]=\nabla f(\boldsymbol{x}^{(t)}), \tag{13.13}$$

> 就称它是当前梯度的**条件无偏**（conditionally unbiased）估计。

条件不能换成不带条件的 $\mathbb{E}[\hat{\boldsymbol{g}}^{(t)}]$。在三项目标上从 $x^{(0)} = 2$ 出发，取 $\alpha = 0.1$。第一步的三种可能是 $x^{(1)} = 1.5, 1.6, 2.3$。若第一步抽到第三项，给定这段历史后当前点是 2.3，第二步读数的条件均值是

$$\mathbb{E}[\hat{g}^{(1)} \mid \mathcal{F}^{(1)}] = f'(2.3) = 2.6.$$

不带条件地平均，则要把三种历史也平均进去，得到的是

$$\mathbb{E}[\hat{g}^{(1)}] = \frac{f'(1.5) + f'(1.6) + f'(2.3)}{3} = 1.6.$$

算法站在 2.3 处需要的是 2.6 这个数，1.6 回答的是另一个问题。

读数的分解　一般的读数未必无偏。把它分成三部分来记录：

$$\hat{\boldsymbol{g}}^{(t)} = \nabla f(\boldsymbol{x}^{(t)}) + \boldsymbol{b}^{(t)} + \boldsymbol{\zeta}^{(t)}, \tag{13.14}$$

其中条件偏差和零条件均值噪声分别是

$$\boldsymbol{b}^{(t)} = \mathbb{E}[\hat{\boldsymbol{g}}^{(t)} \mid \mathcal{F}^{(t)}] - \nabla f(\boldsymbol{x}^{(t)}), \qquad \boldsymbol{\zeta}^{(t)} = \hat{\boldsymbol{g}}^{(t)} - \mathbb{E}[\hat{\boldsymbol{g}}^{(t)} \mid \mathcal{F}^{(t)}].$$

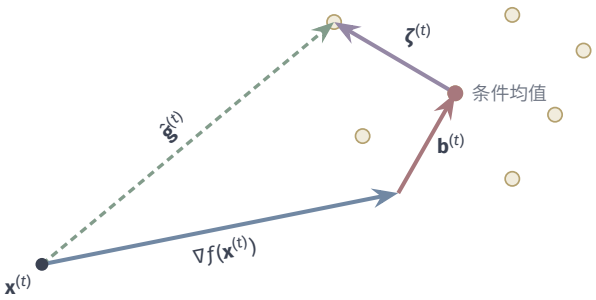


图 13.3　读数的三段分解。蓝色是真梯度，红色是条件偏差，紫色是一次读数偏离条件均值的噪声，绿色虚线是最终拿到的读数。黄色小圆是其他可能的读数，它们围绕条件均值分布。条件无偏的含义是红色线段长度为零，黄色小圆的中心落在蓝色箭头的端点上。

图 13.3说明了两部分误差的不同性质。偏差是系统性的，反复平均也去不掉；噪声的均值为零，累积时会相互抵消一部分。在二阶量上这个区别体现为交叉项消失。噪声的条件均值为零，再由规则 (13.11)，交叉项为零，于是

$$\mathbb{E}[\|\hat{\boldsymbol{g}}^{(t)}\|_2^2 \mid \mathcal{F}^{(t)}] = \|\nabla f(\boldsymbol{x}^{(t)}) + \boldsymbol{b}^{(t)}\|_2^2 + \mathbb{E}[\|\boldsymbol{\zeta}^{(t)}\|_2^2 \mid \mathcal{F}^{(t)}]. \tag{13.15}$$

13.1 随机目标与梯度估计
13.1.1 有限和目标
13.1.2 期望目标
13.1.3 条件无偏与读数误差
13.1.4 循环读取与随机重排
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

后面的分析分别记录这两个量，噪声的条件二阶矩也称条件方差。

例中的偏差与方差 三项目标上均匀抽样的读数无偏，$\boldsymbol{b}^{(t)} = 0$。令 $\delta = x - 1$，式 (13.6)的三个读数写成 $\delta + 4$，$2\delta + 2$，$3\delta - 6$。它们平方的平均是

$$\frac{1}{3}\left[(\delta+4)^2 + (2\delta+2)^2 + (3\delta-6)^2\right] = \frac{14\delta^2 - 20\delta + 56}{3}.$$

减去 $f'(x)^2 = 4\delta^2$，得到条件方差

$$\sigma^2(x) = \frac{2\delta^2 - 20\delta + 56}{3}, \qquad \delta = x - 1. \tag{13.16}$$

在 $x = x^\star$ 处它等于 $56/3 \approx 18.67$，这时完整梯度已经是零，噪声却最明显。在 $x = 2$ 处，$\delta = 1$，方差是 $38/3 \approx 12.67$。

式 (13.16)还说明，方差随 $|x| \to \infty$ 按 δ^2 增长。“条件方差处处不超过某个常数”这种常用假设，即使对最简单的二次目标也只在有界区域内成立。下文使用这类假设时，都理解为沿迭代点成立，它通常需要迭代点停留在有界区域内，这件事本身需要验证。

有偏的读数也容易构造。若按概率 $(1/2, 1/4, 1/4)$ 抽项，又直接使用读数而不作修正，$x = 2$ 处的条件均值是

$$\frac{1}{2}\cdot 5 + \frac{1}{4}\cdot 4 + \frac{1}{4}\cdot(-3) = 2.75,$$

相对 $f'(2) = 2$ 的偏差是 0.75。第 13.3.2小节将说明这种偏差怎样改变实际求解的目标，以及如何用权重把它去掉。

无偏不保证单步下降 条件无偏是平均意义上的性质，一次读数可能与真梯度成钝角。$x = 2$ 处抽到第三项时，读数 -3 和真梯度 2 的乘积是 -6，沿负读数走一步函数值上升。对比之下，条件无偏只保证

$$\mathbb{E}[\langle \nabla f(\boldsymbol{x}^{(t)}), \hat{\boldsymbol{g}}^{(t)} \rangle \mid \mathcal{F}^{(t)}] = \|\nabla f(\boldsymbol{x}^{(t)})\|_2^2 \geq 0.$$

所以随机梯度方法不能用“每步函数值都下降”来分析，要用的是期望意义上的进展。

13.1.4 循环读取与随机重排

上面的条件无偏依赖每步独立抽样。可在有限和目标上，常见的读取方式并不独立。

三种读取顺序 有放回抽样每步独立地均匀抽一个下标，这一轮里有的项可能抽到多次，有的项可能一次也没抽到。固定循环按 $1, 2, \ldots, N$ 的顺序

反复读取。**随机重排**（random reshuffling）每轮开始时把 N 项随机打乱一次，然后无放回地读完。把连续读取 N 项称为一轮，后两种方式的每一轮都恰好读全部的项，图 13.4对比了三种方式。

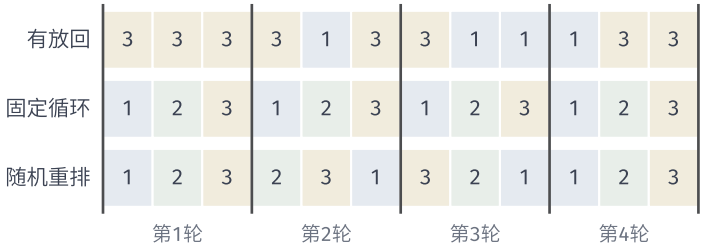


图 13.4　三项目标在四轮内的读取顺序（种子固定）。每格的数字和底色表示读到的项，粗竖线分隔各轮。有放回抽样的一轮可能缺项、重项，固定循环每轮相同，随机重排每轮恰好各读一次，但顺序每轮不同。

一轮之内读数有偏　随机重排打破了逐步条件无偏。在 $x = 2$ 处，设本轮首先读了第三项。给定这段历史，剩下两项的读数是第一项和第二项，平均后是

$$\frac{f_1'(2) + f_2'(2)}{2} = \frac{5 + 4}{2} = 4.5.$$

而完整梯度是 2。这个偏差很好理解：读了负的一项，剩下的项一定偏正。所以式 (13.13)对随机重排的一轮内部不成立，无法直接沿用逐步的条件期望递推。

按整轮来分析　偏差并不是坏事，因为一轮的总和是精确的。把一轮的 N 项读取顺序记为 $\pi_0, \dots, \pi_{N-1}$，轮内迭代点记为 $\boldsymbol{x}_0, \dots, \boldsymbol{x}_N$，步长固定为 α。把每一步的读数在轮初的点 $\boldsymbol{x}_0$ 处展开，

$$\boldsymbol{x}_N = \boldsymbol{x}_0 - \alpha \sum_{k=0}^{N-1} \nabla f_{\pi_k}(\boldsymbol{x}_k).$$

一轮恰好读全部的项，所以各项读数在同一点 $\boldsymbol{x}_0$ 处的和就是 N 倍的完整梯度。在每一项里加减 $\nabla f_{\pi_k}(\boldsymbol{x}_0)$，得到

$$\boldsymbol{x}_N = \boldsymbol{x}_0 - \alpha N \nabla f(\boldsymbol{x}_0) - \alpha \sum_{k=0}^{N-1} \left[\nabla f_{\pi_k}(\boldsymbol{x}_k) - \nabla f_{\pi_k}(\boldsymbol{x}_0)\right]. \tag{13.17}$$

第一部分恰是步长 αN 的一次完整梯度下降，与顺序无关。若各项梯度 L_i-Lipschitz，第二部分的每一项不超过 $L_i \|\boldsymbol{x}_k - \boldsymbol{x}_0\|_2$，而 $\|\boldsymbol{x}_k - \boldsymbol{x}_0\|_2$ 本身是 α 的量级，所以这部分是 α^2 的量级。

一轮之内读到的梯度并不消失，它们的噪声在一轮结束时几乎抵消。有放回抽样没有这个结构，每步噪声 $\alpha\boldsymbol{\zeta}^{(t)}$ 是 α 的量级，一轮的总噪声还是 α 的量级。

三项目标可以直接核对。从 $x_0 = 2$ 开始，步长 $\alpha = 0.1$，顺序为 $3, 1, 2$，轮内的点依次是 2.3, 1.77, 1.416。式 (13.17)的第一部分给出

$$2 - 0.1 \cdot 3 \cdot 2 = 1.4.$$

第二部分的三项里，第三项在 x_0 处读取，差为零；第一项在 2.3 处读取，差是 $1 \cdot 0.3$；第二项在 1.77 处读取，差是 $2 \cdot (-0.23)$。所以第二部分是

$$-0.1 \cdot (0 + 0.3 - 0.46) = 0.016,$$

两部分合计 1.416，与逐步计算一致。

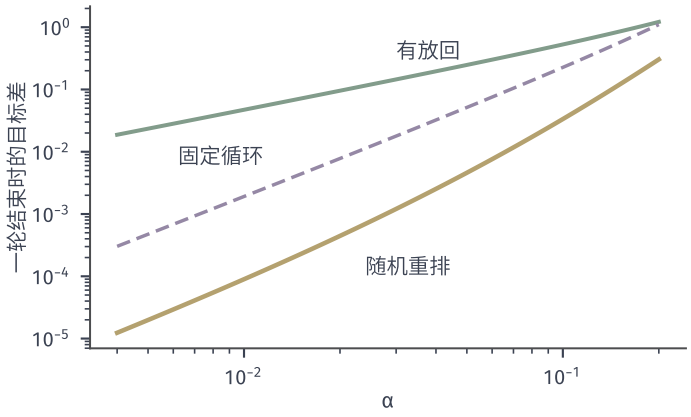


图 13.5 三项目标上固定步长运行至稳定后，一轮结束时的期望目标差与步长的关系，两轴都取对数。数值由精确递推算出，并非抽样估计。绿线是有放回抽样，紫色虚线是固定顺序 $1, 2, 3$，黄线是随机重排。

图 13.5比较了固定步长长期运行后的误差。图中的三条直线斜率不同：步长缩小十倍时，有放回抽样的目标差约缩小十倍；固定循环约缩小一百倍；随机重排缩小的倍数更大，在 $\alpha = 0.1$ 和 0.01 之间约为三百七十倍，曲线向千倍的斜率靠近。在 $\alpha = 0.01$ 时，三者的目标差依次约为 4.7×10^{-2}，1.9×10^{-3}，9.0×10^{-5}。

固定循环的误差是一个确定的偏移，步长固定后迭代点按周期收敛到一条轨道，其离 $x^\star$ 的距离是 α 的量级，目标差是 α^2 的量级，而且偏移大小与读取顺序有关。随机重排把各种顺序平均，轮末偏移的主要部分相互抵消。

这张图只来自一个二次例子，斜率不能直接当作一般定理。一般目标上，随机重排的结论需要对一轮的累积偏差单独分析，证明较长，读者可查阅

相关文献。本章后面的逐步分析都针对有放回抽样或新样本的情形，把它们用于随机重排时要注意上面的差别。

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.2.1 随机梯度下降
13.2.2 步长调度
13.2.3 凸目标的误差与输出
13.2.4 非凸目标的误差与输出
13.2.5 随机邻近梯度
13.2.6 随机块更新
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

13.2 随机梯度方法

上一节说清了读数和真梯度的关系。这就需要回答：把读数直接放进梯度更新后，有限步之内能保证什么？答案由三件事决定：抽样和步长的先后，步长的大小随时间怎样变化，以及最后返回哪个点。

13.2.1 随机梯度下降

主要思想 把梯度下降式中的 $\nabla f(\boldsymbol{x}^{(t)})$ 换成读数，就得到**随机梯度下降**（stochastic gradient descent）：

$$\begin{aligned} \boldsymbol{x}^{(t+1)} &= \boldsymbol{x}^{(t)} - \alpha^{(t)} \hat{\boldsymbol{g}}^{(t)}, \\ \hat{\boldsymbol{g}}^{(t)} &= \nabla f_{i^{(t)}}(\boldsymbol{x}^{(t)}). \end{aligned} \tag{13.18}$$

$i^{(t)}$ 是第 t 步抽到的下标，对期望目标则换成新样本 $\boldsymbol{\xi}^{(t)}$。

可以把它想成下山时每一步只问一位向导。每位向导都有自己的偏好，单独听一位可能走错，但向导们的平均意见是对的。步子小时，连走许多步的总位移接近多位意见的累积，错误相互抵消，走的是平均路线。这个类比说明步长必须小：步子大时一次错误就走出很远，后面来不及纠正。

式 (13.18)的执行顺序有讲究。基本分析要求 $\alpha^{(t)}$ 在抽取 $i^{(t)}$ 之前已经确定，也就是 $\alpha^{(t)}$ 由历史 $\mathcal{F}^{(t)}$ 决定。这样在条件期望中它可以提到外面，式 (13.11)才能用。

变量

- $\boldsymbol{x}^{(t)} \in \mathbb{R}^n$：当前点，在原处更新。
- $i^{(t)}$：本步抽到的下标，用完即弃。
- $\hat{\boldsymbol{g}}^{(t)} \in \mathbb{R}^n$：本步读数。
- $\alpha^{(t)} > 0$：本步步长，抽样前确定。
- $\hat{\boldsymbol{x}}$：最后返回的点，是最后一个迭代点还是某种平均，后面讨论。

初始化 选定初始点、步长规则和总步数 T。例中取

$$x^{(0)} = 2, \qquad \alpha = 0.1,$$

并设前三步抽到的下标依次是 $3, 1, 2$。

每轮更新　对 $t = 0, 1, \dots, T-1$ 依次执行以下步骤。

1. 抽样：独立地均匀抽取下标 $i^{(t)}$。例中第一轮 $i^{(0)} = 3$。
2. 读取：计算本项在当前点的梯度，作为读数 $\hat{\boldsymbol{g}}^{(t)}$。例中第一轮由式 (13.6)，

$$\hat{g}^{(0)} = 3 \cdot 2 - 9 = -3.$$

3. 更新：由式 (13.18)计算新点。例中第一轮

$$x^{(1)} = 2 - 0.1 \cdot (-3) = 2.3.$$

   目标差从 1 变成 1.69，这一步走了上坡。

4. 记录：保存计算输出所需的量。若返回平均点，这里累加 $\alpha^{(t)}\boldsymbol{x}^{(t)}$ 和 $\alpha^{(t)}$；例中只保留当前点。

   例中第二轮 $i^{(1)} = 1$，读数和新点是

$$\hat{g}^{(1)} = 2.3 + 3 = 5.3, \qquad x^{(2)} = 2.3 - 0.53 = 1.77.$$

   例中第三轮 $i^{(2)} = 2$，读数和新点是

$$\hat{g}^{(2)} = 2 \cdot 1.77 = 3.54, \qquad x^{(3)} = 1.77 - 0.354 = 1.416.$$

迭代在预定的 T 步后结束。随机梯度不能用 $\|\hat{\boldsymbol{g}}^{(t)}\|_2$ 作停止判据，因为它在最优点也不趋于零。最终得到 $\hat{\boldsymbol{x}}$，例中经过三次读取得到 $x^{(3)} = 1.416$，目标差降到 0.173。这三次读取的总量等于一次完整梯度的成本。

单步分析：下降量和噪声项　一次更新的后果可以分成两部分：沿真梯度走带来的下降，和读数抖动带来的损失。把更新代入第 5章的下降引理就能把它们分开。

定理 13.3　单步期望进展　设 f 的梯度 L-Lipschitz，读数满足条件无偏 (13.13)，σ_t^2 是噪声 $\boldsymbol{\zeta}^{(t)}$ 的条件方差，$\alpha^{(t)}$ 由 $\mathcal{F}^{(t)}$ 确定。则

$$\mathbb{E}[f(\boldsymbol{x}^{(t+1)}) \mid \mathcal{F}^{(t)}] \le f(\boldsymbol{x}^{(t)}) - \alpha^{(t)}\Big(1 - \frac{L\alpha^{(t)}}{2}\Big)\|\nabla f(\boldsymbol{x}^{(t)})\|_2^2 + \frac{L(\alpha^{(t)})^2}{2}\sigma_t^2. \tag{13.19}$$

证明 证明中省略迭代编号，把当前点、步长和读数简记为 $\boldsymbol{x}, \alpha, \hat{\boldsymbol{g}}$。在下降引理中取 $\boldsymbol{y} = \boldsymbol{x} - \alpha\hat{\boldsymbol{g}}$，得到

$$f(\boldsymbol{x} - \alpha\hat{\boldsymbol{g}}) \le f(\boldsymbol{x}) - \alpha\langle \nabla f(\boldsymbol{x}), \hat{\boldsymbol{g}}\rangle + \frac{L\alpha^2}{2}\|\hat{\boldsymbol{g}}\|_2^2.$$

对两边取 $\mathbb{E}[\cdot \mid \mathcal{F}^{(t)}]$。$\boldsymbol{x}$ 和 α 由历史确定，提到外面。由条件无偏，内积项的条件期望是

$$\mathbb{E}[\langle \nabla f(\boldsymbol{x}), \hat{\boldsymbol{g}}\rangle \mid \mathcal{F}^{(t)}] = \|\nabla f(\boldsymbol{x})\|_2^2.$$

由式 (13.15)，取 $\boldsymbol{b}^{(t)} = \boldsymbol{0}$，二次项的条件期望是

$$\mathbb{E}[\|\hat{\boldsymbol{g}}\|_2^2 \mid \mathcal{F}^{(t)}] = \|\nabla f(\boldsymbol{x})\|_2^2 + \sigma_t^2.$$

两式代入后合并 $\|\nabla f(\boldsymbol{x})\|_2^2$ 的系数，即得式 (13.19)。 ■

和完整梯度的下降估计相比，式 (13.19)只多了右端最后一项。它与 α^2 成正比，而下降量大体与 α 成正比，所以步长足够小时下降占优。接近解时 $\|\nabla f\|_2$ 变小，下降量随之变小，噪声项却不减。两者相等的位置，就是算法再也走不动的地方。

用三项目标从 $x^{(0)} = 2$ 走一步，看这个不等式的两部分。图 13.6画出了三种可能的结果。三个读数给出的新点和目标差分别是

$$x^{(1)} = 1.5,\ 1.6,\ 2.3, \qquad (x^{(1)} - 1)^2 = 0.25,\ 0.36,\ 1.69.$$

抽到第三项时目标差从 1 上升到 1.69，三种结果的平均却下降了：

$$\frac{0.25 + 0.36 + 1.69}{3} \approx 0.767.$$

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.2.1 随机梯度下降
13.2.2 步长调度
13.2.3 凸目标的误差与输出
13.2.4 非凸目标的误差与输出
13.2.5 随机邻近梯度
13.2.6 随机块更新
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

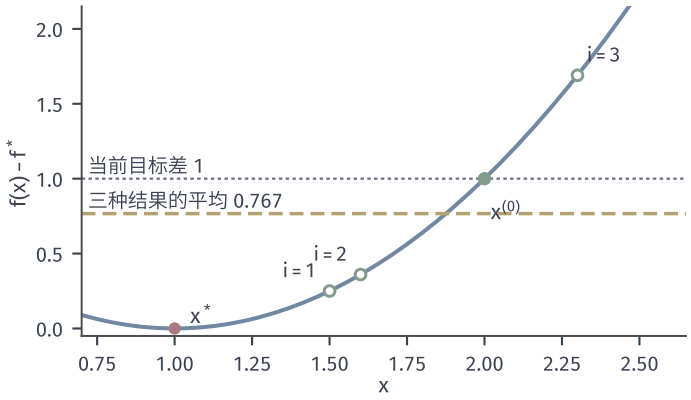


图 13.6 单步的三种结果。蓝线是目标差 $(x-1)^2$，实心绿点是当前点 $x^{(0)}=2$，空心绿点是抽到第 i 项后的新点，步长 $\alpha=0.1$。第三项使目标差上升到 1.69，其余两项使它下降。虚线是三种结果的平均 0.767，低于当前目标差 1。

式 (13.19)给出的数值是相同的。这里 $L=2$，$|f'(2)|=2$，条件方差由式 (13.16)是 $38/3$，所以下降量和噪声项分别是

$$0.1\cdot(1-0.1)\cdot 4 = 0.36, \qquad 0.01\cdot\frac{38}{3}\approx 0.127.$$

于是

$$1-0.36+0.127 = 0.767.$$

目标是二次函数，下降引理取等号，理论值与实际值完全相同。

13.2.2 步长调度

单步分析留下一个问题：步长选大了噪声项大，选小了下降量小，$\alpha^{(t)}$ 该如何随 t 变化？

固定步长：收敛到一个邻域 先看步长不变时发生什么。在强凸目标上，初始误差按几何速度消退，噪声则把误差托在一个不为零的水平。

定理 13.4 固定步长的误差邻域 设 f 的梯度 L-Lipschitz 且 f 是 μ 强凸的，读数条件无偏，且沿迭代点 $\sigma_t^2\le\sigma^2$。若固定步长 $0<\alpha\le 1/L$，则对所有 $T\ge 0$，

$$\mathbb{E}[f(\boldsymbol{x}^{(T)})]-f^\star \le (1-\alpha\mu)^T\big(f(\boldsymbol{x}^{(0)})-f^\star\big)+\frac{\alpha L\sigma^2}{2\mu}. \tag{13.20}$$

证明 记 $e_t = \mathbb{E}[f(\boldsymbol{x}^{(t)})] - f^\star$。因为 $\alpha L \le 1$，所以 $1 - L\alpha/2 \ge 1/2$，式 (13.19)给出

$$\mathbb{E}[f(\boldsymbol{x}^{(t+1)}) \mid \mathcal{F}^{(t)}] \le f(\boldsymbol{x}^{(t)}) - \frac{\alpha}{2}\|\nabla f(\boldsymbol{x}^{(t)})\|_2^2 + \frac{L\alpha^2}{2}\sigma^2.$$

强凸性给出对任意 $\boldsymbol{x}, \boldsymbol{y}$ 成立的下界

$$f(\boldsymbol{y}) \ge f(\boldsymbol{x}) + \langle \nabla f(\boldsymbol{x}), \boldsymbol{y} - \boldsymbol{x} \rangle + \frac{\mu}{2}\|\boldsymbol{y} - \boldsymbol{x}\|_2^2.$$

右端对 $\boldsymbol{y}$ 最小化，最小值在 $\boldsymbol{y} = \boldsymbol{x} - \nabla f(\boldsymbol{x})/\mu$ 处取得，所以

$$f^\star \ge f(\boldsymbol{x}) - \frac{1}{2\mu}\|\nabla f(\boldsymbol{x})\|_2^2.$$

这就是

$$\|\nabla f(\boldsymbol{x})\|_2^2 \ge 2\mu\big(f(\boldsymbol{x}) - f^\star\big).$$

把这个下界代入第一个不等式，两边减去 $f^\star$，再取全期望 (13.12)，得到递推

$$e_{t+1} \le (1 - \alpha\mu) e_t + \frac{L\alpha^2\sigma^2}{2}.$$

由 $\alpha\mu \le \mu/L \le 1$，系数 $1 - \alpha\mu$ 非负，递推可以展开 T 次，得到

$$e_T \le (1 - \alpha\mu)^T e_0 + \frac{L\alpha^2\sigma^2}{2} \sum_{k=0}^{T-1} (1 - \alpha\mu)^k.$$

几何级数不超过 $1/(\alpha\mu)$，代入即得式 (13.20)。 ■

式 (13.20)的第一项随 T 消退，第二项不消退，称为**噪声底** (noise floor)。三个条件各有作用：光滑性使下降引理可用，强凸性把梯度大小换算成目标差，方差上界控制每步的损失。去掉强凸性，这个几何递推就不成立；去掉方差上界，噪声项无法用常数控制。

例中的精确递推 三项目标可以把期望完全算出来。令 $\delta_t = x^{(t)} - 1$，由 $x^{(t+1)} - 1 = \delta_t - \alpha \hat{g}^{(t)}$ 和式 (13.16)，条件期望分别是

$$\mathbb{E}[\delta_{t+1} \mid \mathcal{F}^{(t)}] = (1 - 2\alpha)\delta_t,$$

$$\mathbb{E}[\delta_{t+1}^2 \mid \mathcal{F}^{(t)}] = \Big(1 - 4\alpha + \frac{14}{3}\alpha^2\Big)\delta_t^2 - \frac{20}{3}\alpha^2\delta_t + \frac{56}{3}\alpha^2.$$

当 $\alpha < 6/7$ 时，δ_t^2 的系数小于 1，且 $\mathbb{E}[\delta_t] \to 0$。令 $\mathbb{E}[\delta_t^2]$ 的稳态值为 s，在第二式中取全期望并令 $\mathbb{E}[\delta_t] = 0$，它满足

$$\Big(4\alpha - \frac{14}{3}\alpha^2\Big)s = \frac{56}{3}\alpha^2.$$

解得

$$\lim_{t\to\infty} \mathbb{E}[f(x^{(t)}) - f^\star] = \frac{28\alpha}{6 - 7\alpha}. \tag{13.21}$$

$\alpha = 0.1$ 时噪声底约为 0.528，$\alpha = 0.02$ 时约为 0.096。

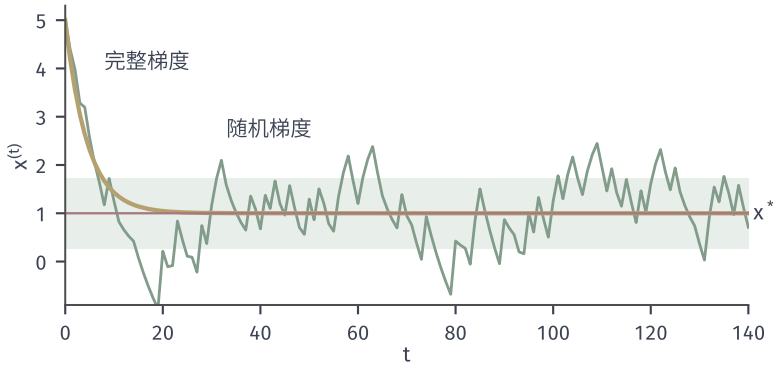


图 13.7 三项目标上从 $x^{(0)} = 5$ 出发，步长 $\alpha = 0.1$（种子固定）的一条路径。绿线是随机梯度，黄线是完整梯度，红线是 $x^\star = 1$。绿底带的半宽是式 (13.21)的平方根 0.727，即稳态下均方根偏差。

图 13.7是一条实际路径。开始的十几步里绿线和黄线几乎重合：离解很远时信号强于噪声，抽到哪一项都往下走。之后黄线停在解上，绿线在一条带内不停抖动，这条带就是噪声底的样子。

固定、递减与分段 固定步长的两部分误差互相拉扯：大的 α 使初始误差消得快，噪声底却高；小的 α 相反。要想噪声底趋于零，步长就得逐渐减小。

经典的递减条件是

$$\sum_{t=0}^{\infty} \alpha^{(t)} = \infty, \qquad \sum_{t=0}^{\infty} (\alpha^{(t)})^2 < \infty. \tag{13.22}$$

第一个要求表示累计可走的距离没有上限，初始点再远也到得了；第二个要求表示噪声积累的总量有限[1]。例如 $\alpha^{(t)} = c/(t + t_0)$ 同时满足两者。

分段调整介于两者之间：先用较大的步长，到达噪声底后减半，再走一段。每段把噪声底压低一半，代价是每段需要的步数翻倍。图 13.8(a) 比较了几种调度，图中的曲线由递推精确算出。

[1] H. Robbins, S. Monro, *A Stochastic Approximation Method* In The Annals of Mathematical Statistics, 1951, vol. 22, no. 3, pp. 400–407

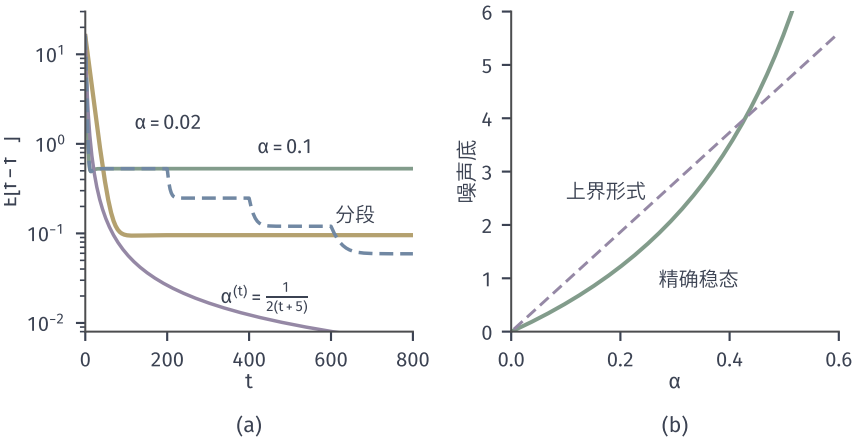


图 13.8 三项目标的步长调度，由精确递推算出，$x^{(0)} = 5$。(a) 绿线和黄线是固定步长 0.1 和 0.02，紫线是 $\alpha^{(t)} = 1/(2(t+5))$，蓝色虚线是从 0.1 起每 200 步减半。固定步长最后变平，大步长到得早而停得高；递减步长持续下降。(b) 绿线是噪声底的精确值 (13.21)，紫色虚线是式 (13.20)第二项取 $\sigma^2 = 56/3$ 的形式；后者只代入最优点处的方差，并非严格上界。步长较大时迭代离解较远，实际方差更大，绿线超过虚线。

时间单位 调度写成 t 的函数时，要说明 t 计的是什么。常见的单位有三种：更新次数、读取的样本量、完整遍历的轮数。批量为 B、项数为 N 时，一轮是 N/B 次更新，读取 N 个样本。

同一句“每 200 步减半”，用更新次数计时，批量改变后读取量不同；用样本量计时，批量改变后更新次数不同。批量、并行度或数据量一变，换算不当的调度含义就变了。式 (13.20)和式 (13.22)中的 t 都是更新次数。

步长依赖本轮读数时 前面一直要求 $\alpha^{(t)}$ 在抽样之前确定。步长若依赖本轮读数，$\mathbb{E}[\alpha^{(t)}\hat{\boldsymbol{g}}^{(t)} \mid \mathcal{F}^{(t)}]$ 不再等于 $\alpha^{(t)}\nabla f(\boldsymbol{x}^{(t)})$，因为步长和方向相关。

在三项目标上看一个具体的后果。取只保留读数符号的规则，步长 $\alpha/|\hat{g}|$，每步走固定距离。在 $x = 0.5$ 处，三个读数是 $3.5, 1, -7.5$，真梯度是 -1，应该向右走。这三个读数的符号是两正一负，平均更新是

$$-\alpha \cdot \frac{1+1-1}{3} = -\frac{\alpha}{3},$$

平均向左走，方向错了。

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.2.1 随机梯度下降
13.2.2 步长调度
13.2.3 凸目标的误差与输出
13.2.4 非凸目标的误差与输出
13.2.5 随机邻近梯度
13.2.6 随机块更新
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

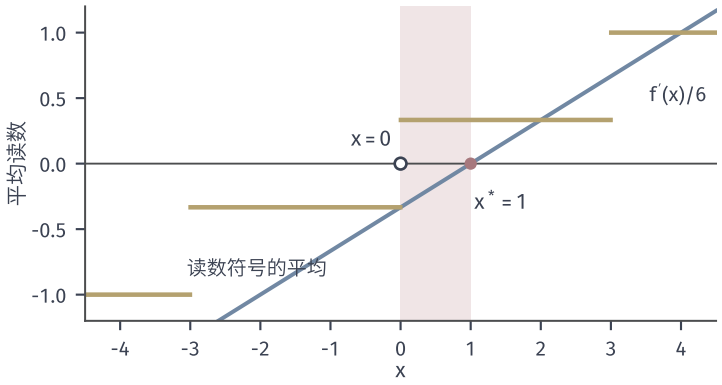


图 13.9 步长与读数相关时平均方向可能错误。蓝线是真梯度 $f'(x)$ 按比例缩小 6 倍，零点是 $x^\star = 1$；黄色阶梯是三个读数符号的平均，零点是 $x = 0$。红底区间 $(0, 1)$ 内两者异号，按读数符号走的平均方向与真梯度相反。

图 13.9说明了问题的严重性：这条规则的平均动力学的零点是 $x = 0$，即各项最小点 $-3, 0, 3$ 的中位数，而不是 $x^\star = 1$。缩小 α 也改变不了这一点，因为偏差存在于平均方向之中。依赖读数的步长并非都不能用，后文讨论的方法多属于这一类，但必须分别分析步长与方向的相关性。

13.2.3 凸目标的误差与输出

前面的噪声底结论依赖强凸性。对一般的凸目标，$f - f^\star$ 与梯度大小没有固定的换算关系，下降引理的路线走不通。这一小节换一个量来追踪：到最优解的距离。

距离递推与平均点 距离的好处是展开之后能用凸性。把更新代入 $\|\boldsymbol{x}^{(t+1)} - \boldsymbol{x}^\star\|_2^2$，内积项由凸性转成目标差，所得到的结论是对迭代点的加权和成立的。

为了从加权和回到一个点，需要 Jensen 不等式：若 f 凸，$\lambda_t \ge 0$，$\sum_t \lambda_t = 1$，则

$$f\Big(\sum_t \lambda_t \boldsymbol{x}^{(t)}\Big) \le \sum_t \lambda_t f(\boldsymbol{x}^{(t)}).$$

两个点的情形就是凸函数的定义，多个点时对点数作归纳即得。

定理 13.5 凸目标的加权平均点 设 f 凸且可微，存在最小点 $\boldsymbol{x}^\star$，读数条件无偏，且沿迭代点读数的条件二阶矩不超过 G^2，步长 $\alpha^{(t)} > 0$ 事先确定。记 $R = \|\boldsymbol{x}^{(0)} - \boldsymbol{x}^\star\|_2$，$A_T = \sum_{t=0}^{T-1} \alpha^{(t)}$，加权平均点

$$\bar{\boldsymbol{x}}^{(T)} = \frac{1}{A_T} \sum_{t=0}^{T-1} \alpha^{(t)} \boldsymbol{x}^{(t)}. \tag{13.23}$$

则

$$\mathbb{E}[f(\bar{\boldsymbol{x}}^{(T)})] - f^\star \le \frac{R^2 + G^2 \sum_{t=0}^{T-1} (\alpha^{(t)})^2}{2A_T}. \tag{13.24}$$

证明 记 d_t 为 $\|\boldsymbol{x}^{(t)} - \boldsymbol{x}^\star\|_2^2$ 的期望。展开平方，得到

$$\|\boldsymbol{x}^{(t+1)} - \boldsymbol{x}^\star\|_2^2 = \|\boldsymbol{x}^{(t)} - \boldsymbol{x}^\star\|_2^2 - 2\alpha^{(t)} \langle \hat{\boldsymbol{g}}^{(t)}, \boldsymbol{x}^{(t)} - \boldsymbol{x}^\star \rangle + (\alpha^{(t)})^2 \|\hat{\boldsymbol{g}}^{(t)}\|_2^2.$$

取 $\mathbb{E}[\cdot \mid \mathcal{F}^{(t)}]$。$\boldsymbol{x}^{(t)} - \boldsymbol{x}^\star$ 由历史确定，内积项由条件无偏变成 $\langle \nabla f(\boldsymbol{x}^{(t)}), \boldsymbol{x}^{(t)} - \boldsymbol{x}^\star \rangle$。凸性给出

$$\langle \nabla f(\boldsymbol{x}^{(t)}), \boldsymbol{x}^{(t)} - \boldsymbol{x}^\star \rangle \ge f(\boldsymbol{x}^{(t)}) - f^\star.$$

再用二阶矩的上界并取全期望，得到递推

$$d_{t+1} \le d_t - 2\alpha^{(t)} \big(\mathbb{E}[f(\boldsymbol{x}^{(t)})] - f^\star \big) + (\alpha^{(t)})^2 G^2.$$

对 $t = 0, \dots, T-1$ 求和，左右的 d_t 逐项相消，再丢掉非负的 d_T，得到

$$2 \sum_{t=0}^{T-1} \alpha^{(t)} \big(\mathbb{E}[f(\boldsymbol{x}^{(t)})] - f^\star \big) \le R^2 + G^2 \sum_{t=0}^{T-1} (\alpha^{(t)})^2.$$

两边除以 $2A_T$，并对 $\lambda_t = \alpha^{(t)} / A_T$ 使用 Jensen 不等式，即得式 (13.24)。 ■

固定步长 α 时，式 (13.24)的右端是 $R^2/(2\alpha T) + \alpha G^2/2$。对 α 求最小，取 $\alpha = R/(G\sqrt{T})$，得到

$$\mathbb{E}[f(\bar{\boldsymbol{x}}^{(T)})] - f^\star \le \frac{RG}{\sqrt{T}}. \tag{13.25}$$

要把目标差减小十倍，步数要增加一百倍。

二阶矩的上界 G^2 包含了梯度本身，在全空间常常不成立。若 f 还有 L-Lipschitz 梯度，条件可以放宽为条件方差不超过 σ^2。在凸的 L-光滑函数上，从 $\boldsymbol{x}$ 走一步 $\boldsymbol{x} - \nabla f(\boldsymbol{x})/L$，由下降引理，

$$f^\star \le f(\boldsymbol{x}) - \frac{1}{2L} \|\nabla f(\boldsymbol{x})\|_2^2.$$

于是梯度大小被目标差控制，读数的二阶矩满足

$$\mathbb{E}[\|\hat{\boldsymbol{g}}^{(t)}\|_2^2 \mid \mathcal{F}^{(t)}] \le 2L \big(f(\boldsymbol{x}^{(t)}) - f^\star \big) + \sigma^2.$$

把它代入上面的递推，当 $\alpha \le 1/(2L)$ 时，由 $1-\alpha L \ge 1/2$，同样的求和给出

$$\mathbb{E}[f(\bar{\boldsymbol{x}}^{(T)})] - f^\star \le \frac{R^2}{\alpha T} + \alpha \sigma^2. \tag{13.26}$$

取 $\alpha = \min\{1/(2L), R/(\sigma\sqrt{T})\}$，右端不超过 $2LR^2/T + 2R\sigma/\sqrt{T}$。第一项是完整梯度下降的速率，第二项是噪声带来的代价；$\sigma = 0$ 时退回确定情形。

强凸性的改善　强凸性使距离递推有了收缩，步长可以取到 $1/t$ 的量级。

定理 13.6　强凸目标的递减步长　设 f 可微且 μ 强凸，读数条件无偏，沿迭代点读数的条件二阶矩不超过 G^2，$\alpha^{(t)} = 1/(\mu(t+1))$。则对所有 $T \ge 1$，

$$\mathbb{E}[\|\boldsymbol{x}^{(T)} - \boldsymbol{x}^\star\|_2^2] \le \frac{G^2}{\mu^2 T}. \tag{13.27}$$

证明　强凸下界中分别取 $(\boldsymbol{x}, \boldsymbol{x}^\star)$ 和 $(\boldsymbol{x}^\star, \boldsymbol{x})$，相加并用 $\nabla f(\boldsymbol{x}^\star) = \boldsymbol{0}$，得到

$$\langle \nabla f(\boldsymbol{x}), \boldsymbol{x} - \boldsymbol{x}^\star \rangle \ge \mu \|\boldsymbol{x} - \boldsymbol{x}^\star\|_2^2.$$

沿用定理 13.5证明中的展开，得到

$$d_{t+1} \le (1 - 2\alpha^{(t)}\mu) d_t + (\alpha^{(t)})^2 G^2 = \Big(1 - \frac{2}{t+1}\Big) d_t + \frac{G^2}{\mu^2 (t+1)^2}.$$

对 T 作归纳。$T = 1$ 时，取 $t = 0$，系数是 -1，由 $d_0 \ge 0$ 有 $d_1 \le G^2/\mu^2$，结论成立。

设 $d_t \le G^2/(\mu^2 t)$，其中 $t \ge 1$，此时系数 $1 - 2/(t+1)$ 非负。代入递推，得到

$$d_{t+1} \le \frac{G^2}{\mu^2}\Big[\frac{t-1}{t(t+1)} + \frac{1}{(t+1)^2}\Big].$$

只需证明方括号不超过 $1/(t+1)$，即 $\frac{t-1}{t} + \frac{1}{t+1} \le 1$。这等价于 $\frac{1}{t+1} \le \frac{1}{t}$，成立。 ∎

强凸假设和全空间的 G^2 是矛盾的，因为强凸函数的梯度无界。定理中的条件要理解为迭代点在有界集内，通常由投影到有界闭凸集来保证，投影不增大到 $\boldsymbol{x}^\star$ 的距离，上面的递推继续成立。

把结论总结成对比：

条件	步长	期望误差
凸，二阶矩有界	$\dfrac{R}{G\sqrt{T}}$	平均点目标差 $\dfrac{RG}{\sqrt{T}}$
凸，光滑，方差有界	$\min\left\{\dfrac{1}{2L}, \dfrac{R}{\sigma\sqrt{T}}\right\}$	平均点目标差 $\dfrac{2LR^2}{T} + \dfrac{2R\sigma}{\sqrt{T}}$
强凸，二阶矩有界	$\dfrac{1}{\mu(t+1)}$	末点距离平方 $\dfrac{G^2}{\mu^2 T}$
强凸，光滑，方差有界	固定，$\alpha \le \dfrac{1}{L}$	末点目标差，含噪声底

表 13.1　本小节及上一小节的保证。表中“末点”指最后一个迭代点，“光滑”指梯度 L-Lipschitz。前两行的结论针对平均点，后两行针对末点。

最后一点与平均点　定理 13.5的保证属于平均点，不能搬到任意一个迭代点上。平均值小只说明大多数项小：序列 $0, 0, \dots, 0, 3$ 的平均可以任意小，而最后一项是 3。一般凸目标上最后一点的保证需要单独证明，所得的速率通常比平均点差，具体分析较长，读者可查阅专门的文献。

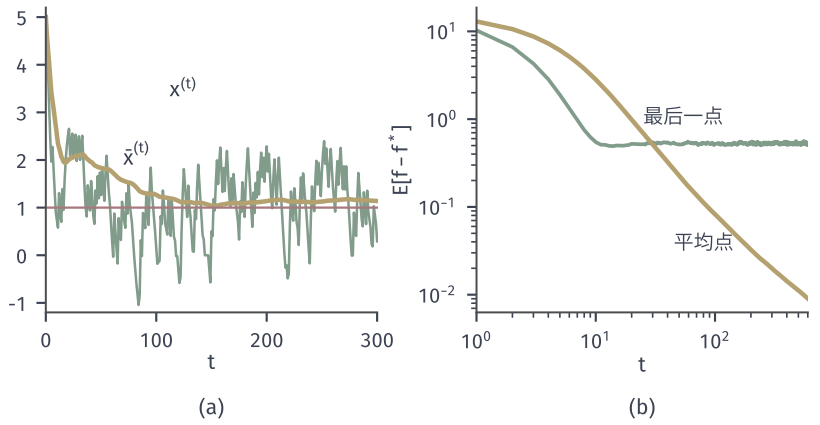


图 13.10　三项目标上固定步长 $\alpha = 0.1$，从 $x^{(0)} = 5$ 出发。(a) 同一条路径上最后一点 $x^{(t)}$（绿）和从头算起的平均点 $\bar{x}^{(t)}$（黄），红线是 $x^\star$。(b)4000 次独立运行的平均目标差（种子固定），两轴取对数。$t = 600$ 时最后一点的目标差约为 0.53，平均点约为 0.009。

在三项目标上平均的作用很明显。图 13.10(a) 的绿线一直在抖，黄线很快贴近解。(b) 说明最后一点停在噪声底 0.53，平均点的目标差继续下降。原因是抖动在解的两侧来回，平均时相互抵消，而初始段的影响被越来越多的项稀释。平均点要付出的代价是多存一个向量，并且受早期迭代点的拖累，因此实践中也常只平均后面一段。

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.2.1 随机梯度下降
13.2.2 步长调度
13.2.3 凸目标的误差与输出
13.2.4 非凸目标的误差与输出
13.2.5 随机邻近梯度
13.2.6 随机块更新
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

13.2.4 非凸目标的误差与输出

目标非凸时，到最小点的距离既不能保证下降，也可能不止一个最小点。只能回到单步下降，评价的量也要换成梯度大小。

累加下降量 式 (13.19)不需要凸性，把它沿 t 累加，左边望远镜相消，剩下函数值的总下降量，它受目标下界限制。

定理 13.7 非凸目标的平均平方梯度 设 f 有下界 $f_{\inf}$，梯度 L-Lipschitz，读数条件无偏且沿迭代点 $\sigma_t^2 \le \sigma^2$，步长事先确定且 $0 < \alpha^{(t)} \le 1/L$。记 $\Delta = f(\boldsymbol{x}^{(0)}) - f_{\inf}$，$A_T = \sum_{t=0}^{T-1} \alpha^{(t)}$。则

$$\frac{1}{A_T}\sum_{t=0}^{T-1} \alpha^{(t)} \mathbb{E}[\|\nabla f(\boldsymbol{x}^{(t)})\|_2^2] \le \frac{2\Delta + L\sigma^2 \sum_{t=0}^{T-1} (\alpha^{(t)})^2}{A_T}. \tag{13.28}$$

证明 由 $\alpha^{(t)} L \le 1$，式 (13.19)的系数 $1 - L\alpha^{(t)}/2 \ge 1/2$。取全期望，得到

$$\frac{\alpha^{(t)}}{2}\mathbb{E}[\|\nabla f(\boldsymbol{x}^{(t)})\|_2^2] \le \mathbb{E}[f(\boldsymbol{x}^{(t)})] - \mathbb{E}[f(\boldsymbol{x}^{(t+1)})] + \frac{L(\alpha^{(t)})^2}{2}\sigma^2.$$

对 $t = 0, \dots, T-1$ 求和，函数值逐项相消，只剩 $f(\boldsymbol{x}^{(0)}) - \mathbb{E}[f(\boldsymbol{x}^{(T)})]$，由下界，它不超过 Δ。于是

$$\frac{1}{2}\sum_{t=0}^{T-1} \alpha^{(t)} \mathbb{E}[\|\nabla f(\boldsymbol{x}^{(t)})\|_2^2] \le \Delta + \frac{L\sigma^2}{2}\sum_{t=0}^{T-1} (\alpha^{(t)})^2.$$

两边乘以 $2/A_T$，即得式 (13.28)。 ■

固定步长时，右端是 $2\Delta/(\alpha T) + L\sigma^2\alpha$。取

$$\alpha = \min\Big\{\frac{1}{L}, \sqrt{\frac{2\Delta}{L\sigma^2 T}}\Big\},$$

并利用 $1/\alpha$ 不超过两个倒数之和，得到

$$\frac{1}{T}\sum_{t=0}^{T-1} \mathbb{E}[\|\nabla f(\boldsymbol{x}^{(t)})\|_2^2] \le \frac{2L\Delta}{T} + 2\sqrt{\frac{2L\Delta\sigma^2}{T}}. \tag{13.29}$$

按权重随机返回 式 (13.28)的左端是平均，还不是某个点的性质。非凸时平均点没有 Jensen 不等式可用，点的平均甚至可能落在山顶上。解决办法

是把平均变成一个随机的点：以概率 $\alpha^{(t)}/A_T$ 抽取下标 τ，返回 $\boldsymbol{x}^{(\tau)}$。由全期望公式，

$$\mathbb{E}[\|\nabla f(\boldsymbol{x}^{(\tau)})\|_2^2] = \frac{1}{A_T}\sum_{t=0}^{T-1}\alpha^{(t)}\mathbb{E}[\|\nabla f(\boldsymbol{x}^{(t)})\|_2^2].$$

所以左端是这个随机输出的期望平方梯度。

用一个能实际计算的非凸例子来看。取 $f_i(x) = 1-\cos x + c_i x, (c_1, c_2, c_3) = (-2, 0, 2)$，则

$$f(x) = 1 - \cos x, \qquad f_i'(x) = \sin x + c_i.$$

这里 $f_{\inf} = 0$，$L = 1$，条件方差恰好是常数 $\sigma^2 = 8/3$，所有假设都严格成立。取 $x^{(0)} = 2.5$，$\alpha = 0.1$，$T = 800$，则 $\Delta = 1 - \cos 2.5 \approx 1.80$，上界是

$$\frac{2\cdot 1.80}{0.1\cdot 800} + 1\cdot\frac{8}{3}\cdot 0.1 \approx 0.045 + 0.267 = 0.312.$$

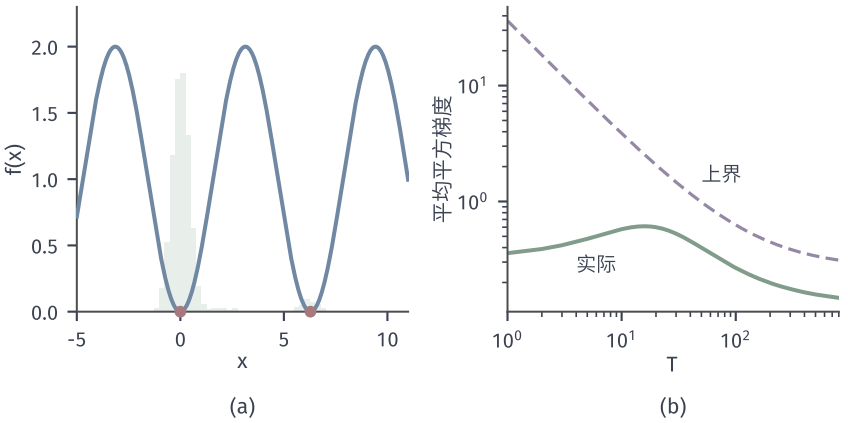


图 13.11 非凸目标 $f(x) = 1 - \cos x$ 上 6000 次独立运行的随机梯度方法（种子固定），$x^{(0)} = 2.5$，$\alpha = 0.1$。(a) 蓝线是目标函数，红点是最小点 $x = 0$ 和 2π，绿底直方图是 $T = 800$ 时按权重随机返回的点的分布（纵向已缩放）。(b) 绿线是 T 步内平方梯度的平均，紫色虚线是式 (13.28)的上界，两轴取对数。

图 13.11(b) 显示实际平均约为 0.147，低于上界 0.312。上界的第二项 $\alpha L\sigma^2$ 对应的正是噪声底，这个上界在 T 增大时不趋于零，要趋于零必须同时缩小 α。图 (a) 中大多数返回点集中在 $x = 0$ 附近，少数越过山峰到了 2π 附近。

这个结论不说明什么 式 (13.28)只评价一阶驻定。小梯度的点可能在鞍点或平坦的高处，它与局部极小的距离没有被保证；能否离开鞍点是第 10章的主题。

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.2.1 随机梯度下降
13.2.2 步长调度
13.2.3 凸目标的误差与输出
13.2.4 非凸目标的误差与输出
13.2.5 随机邻近梯度
13.2.6 随机块更新
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

它也是期望界，不是逐路径保证。由 Markov 不等式，对 $\varepsilon>0$，

$$\mathbb{P}\big(\|\nabla f(\boldsymbol{x}^{(\tau)})\|_2^2 \ge \varepsilon\big) \le \frac{\mathbb{E}[\|\nabla f(\boldsymbol{x}^{(\tau)})\|_2^2]}{\varepsilon},$$

只给出一次运行的概率控制。随着 $t\to\infty$ 路径本身的行为，例如几乎处处收敛，需要鞅收敛等工具，可参考卷九第 3 章“离散时间随机过程”。

13.2.5 随机邻近梯度

目标带非光滑项时，上面的更新不能直接用。本小节要解决的问题是：非光滑项确定而光滑项需要抽样，邻近步该怎样接上随机读数？

主要思想　设复合目标 $F(\boldsymbol{x})=f(\boldsymbol{x})+h(\boldsymbol{x})$，其中 f 是光滑的有限和或期望目标，h 是适当、下半连续的凸函数，且邻近映射可以计算。**随机邻近梯度法**（stochastic proximal gradient method）只对光滑部分抽样，h 则每步精确处理：

$$\boldsymbol{x}^{(t+1)}=\operatorname{prox}_{\alpha^{(t)}h}\big(\boldsymbol{x}^{(t)}-\alpha^{(t)}\hat{\boldsymbol{g}}^{(t)}\big), \tag{13.30}$$

其中邻近映射的定义和计算见第 11章。h 不参与抽样，只在邻近步中出现，这样 $\hat{\boldsymbol{g}}^{(t)}$ 的条件无偏性只关系到 f。

计算过程　在三项目标上加 $h(x)=\gamma|x|$，取 $\gamma=1$。复合目标的最优解满足 $2x-2+\gamma=0$，所以 $x^\star=0.5$，它是正的，与 $|x|$ 的导数取 $+1$ 相符。邻近映射是软阈值：

$$\operatorname{prox}_{\alpha h}(z)=\operatorname{sign}(z)\max\{|z|-\alpha\gamma,0\}.$$

变量与第 13.2.1小节相同，多一个非光滑项的参数。每轮更新三步：抽样下标 $i^{(t)}$，走一步随机梯度得到中间点 $\boldsymbol{z}^{(t)}$，求 $\boldsymbol{z}^{(t)}$ 的邻近点作为 $\boldsymbol{x}^{(t+1)}$。

例中取 $x^{(t)}=0.2$，$\alpha=0.1$，阈值是 0.1。三项读数分别是 $3.2, 0.4, -8.4$，完整梯度是 -1.6。走完梯度步的三种结果是

$$z=-0.12,\quad z=0.16,\quad z=1.04,$$

对应的邻近点分别是

$$-0.02,\quad 0.06,\quad 0.94.$$

随机更新的均值不等于精确更新　三个邻近点的平均是 0.327。精确更新则先平均梯度，$z=0.36$，邻近点是 0.26。两者不相等。

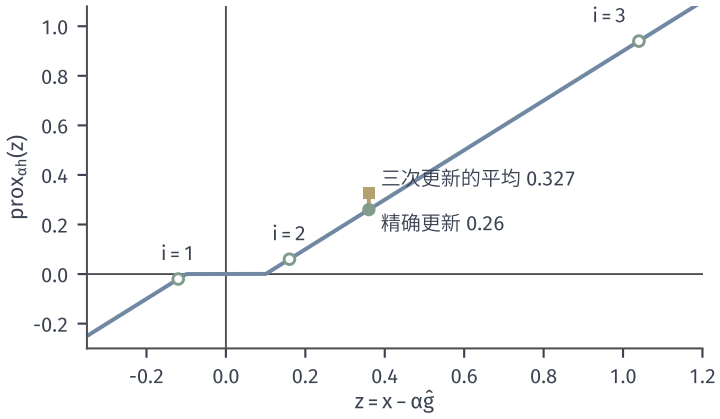


图 13.12 邻近映射的非线性。蓝线是阈值为 0.1 的软阈值函数。三个空心点是三种读数对应的结果。实心绿点是先平均 z 再求邻近点的精确更新，黄方块是三次邻近点的平均。两点之差来自软阈值在零附近的弯折。

图 13.12说明了原因：邻近映射是非线性的，先平均再映射与先映射再平均结果不同。所以即使 $\hat{\boldsymbol{g}}^{(t)}$ 条件无偏，随机更新的均值一般也不等于精确更新。这就是不能直接沿用无偏分析的地方。

误差的评价 凸情形用复合目标差评价。证明的关键是引入精确更新点，把含噪声的内积拆开。

定理 13.8 随机邻近梯度的平均点 设 f 凸且梯度 L-Lipschitz，h 适当、下半连续、凸，$F = f + h$ 有最小点 $\boldsymbol{x}^\star$。读数条件无偏，沿迭代点 $\sigma_t^2 \le \sigma^2$，固定步长 $0 < \alpha \le 1/L$。记 $R = \|\boldsymbol{x}^{(0)} - \boldsymbol{x}^\star\|_2$，$\bar{\boldsymbol{x}}^{(T)}$ 为 $\boldsymbol{x}^{(1)}, \dots, \boldsymbol{x}^{(T)}$ 的算术平均，则

$$\mathbb{E}[F(\bar{\boldsymbol{x}}^{(T)})] - F(\boldsymbol{x}^\star) \le \frac{R^2}{2\alpha T} + \alpha\sigma^2. \tag{13.31}$$

证明 证明中把当前点和下一点记为 $\boldsymbol{x}, \boldsymbol{x}^+$，噪声记为 $\boldsymbol{\zeta}$，比较点 $\boldsymbol{u}$ 取为 $\boldsymbol{x}^\star$。由下降引理和 f 的凸性，

$$f(\boldsymbol{x}^+) \le f(\boldsymbol{u}) + \langle \nabla f(\boldsymbol{x}), \boldsymbol{x}^+ - \boldsymbol{u} \rangle + \frac{L}{2}\|\boldsymbol{x}^+ - \boldsymbol{x}\|_2^2.$$

邻近点的最优性条件说明 $(\boldsymbol{x} - \alpha\hat{\boldsymbol{g}}^{(t)} - \boldsymbol{x}^+)/\alpha$ 是 h 在 $\boldsymbol{x}^+$ 处的次梯度，于是

$$h(\boldsymbol{x}^+) \le h(\boldsymbol{u}) - \langle \hat{\boldsymbol{g}}^{(t)}, \boldsymbol{x}^+ - \boldsymbol{u} \rangle + \frac{1}{\alpha}\langle \boldsymbol{x} - \boldsymbol{x}^+, \boldsymbol{x}^+ - \boldsymbol{u} \rangle.$$

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.2.1 随机梯度下降
13.2.2 步长调度
13.2.3 凸目标的误差与输出
13.2.4 非凸目标的误差与输出
13.2.5 随机邻近梯度
13.2.6 随机块更新
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

把两式相加。对最后的内积使用恒等式

$$2\langle \boldsymbol{x}-\boldsymbol{x}^{+},\boldsymbol{x}^{+}-\boldsymbol{u}\rangle = \|\boldsymbol{x}-\boldsymbol{u}\|_2^2 - \|\boldsymbol{x}^{+}-\boldsymbol{u}\|_2^2 - \|\boldsymbol{x}^{+}-\boldsymbol{x}\|_2^2.$$

由 $\alpha \le 1/L$，$\|\boldsymbol{x}^{+}-\boldsymbol{x}\|_2^2$ 的系数 $L/2 - 1/(2\alpha)$ 非正，可以丢掉，得到

$$F(\boldsymbol{x}^{+}) - F(\boldsymbol{u}) \le \frac{\|\boldsymbol{x}-\boldsymbol{u}\|_2^2 - \|\boldsymbol{x}^{+}-\boldsymbol{u}\|_2^2}{2\alpha} - \langle \boldsymbol{\zeta}, \boldsymbol{x}^{+}-\boldsymbol{u}\rangle.$$

最后一项里 $\boldsymbol{x}^{+}$ 依赖 $\boldsymbol{\zeta}$，条件期望不为零。这里引入用真梯度算出的精确更新点

$$\boldsymbol{p} = \operatorname{prox}_{\alpha h}\big(\boldsymbol{x} - \alpha \nabla f(\boldsymbol{x})\big).$$

它由历史确定，于是

$$\mathbb{E}[\langle \boldsymbol{\zeta}, \boldsymbol{p}-\boldsymbol{u}\rangle \mid \mathcal{F}^{(t)}] = 0.$$

邻近映射是非扩张的，两个输入相差 $\alpha\boldsymbol{\zeta}$，所以 $\boldsymbol{x}^{+}$ 与 $\boldsymbol{p}$ 的距离不超过 $\alpha\|\boldsymbol{\zeta}\|_2$。再由 Cauchy–Schwarz 不等式，

$$-\langle \boldsymbol{\zeta}, \boldsymbol{x}^{+}-\boldsymbol{p}\rangle \le \alpha\|\boldsymbol{\zeta}\|_2^2.$$

取条件期望，得到

$$\mathbb{E}[F(\boldsymbol{x}^{+}) \mid \mathcal{F}^{(t)}] - F(\boldsymbol{u}) \le \frac{\|\boldsymbol{x}-\boldsymbol{u}\|_2^2 - \mathbb{E}[\|\boldsymbol{x}^{+}-\boldsymbol{u}\|_2^2 \mid \mathcal{F}^{(t)}]}{2\alpha} + \alpha\sigma^2.$$

取全期望后对 $t = 0, \dots, T-1$ 求和，距离项逐项相消，再除以 T，并由 F 的凸性用 Jensen 不等式，即得式 (13.31)。 ■

非凸的光滑部分要用另一种度量。精确邻近梯度映射是

$$\boldsymbol{G}_{\alpha}(\boldsymbol{x}) = \frac{1}{\alpha}\Big[\boldsymbol{x} - \operatorname{prox}_{\alpha h}\big(\boldsymbol{x} - \alpha\nabla f(\boldsymbol{x})\big)\Big], \tag{13.32}$$

$\boldsymbol{G}_{\alpha}(\boldsymbol{x}) = \boldsymbol{0}$ 恰好是复合目标的驻点条件。把 ∇f 换成读数就得到含噪声的读数，它不能代替驻点残差。例中 $x = 0.2$ 处 $G_{\alpha} = (0.2 - 0.26)/0.1 = -0.6$，而三次含噪读数是 2.2，1.4，$-7.4$，平均 -1.27，既不等于 -0.6，也没有哪一次接近它。这种读数变小，不能说明当前点接近驻点。

13.2.6 随机块更新

第 12章的分块方法每步只更新变量的一块。本节的方法每步只读一部分目标项。两者可以同时使用，这时要说清每种随机选择各带来什么。

两种随机选择 把变量分成 J 块，第 j 块的偏梯度记为 $\nabla_j f$，$\boldsymbol{U}_j$ 把第 j 块的向量放回全长向量的相应位置，其余分量补零。随机块更新在第 t 步选一块 $j^{(t)}$，抽一项 $i^{(t)}$，然后

$$\boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} - \alpha_{j^{(t)}} \boldsymbol{U}_{j^{(t)}} \nabla_{j^{(t)}} f_{i^{(t)}}(\boldsymbol{x}^{(t)}). \tag{13.33}$$

选块是对变量抽样，选项是对目标项抽样，图 13.13用一张二维表表示。

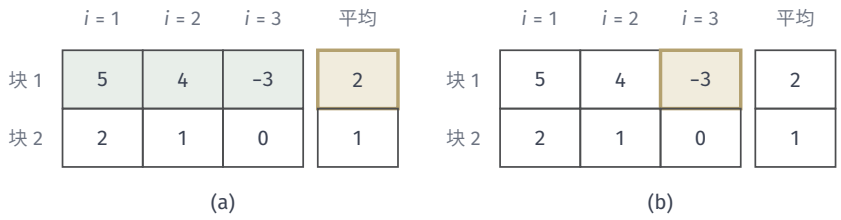


图 13.13 读取一次的范围。行是变量块，列是目标项，表中数字是第 i 项对第 j 块的偏导。(a) 只随机选块：读完一行所有项（绿底），得到精确的偏梯度（黄框）。(b) 同时选块和选项：只读一格（黄框），这个数是偏导的一次读数。

用二元的例子把数字写出来。把贯穿例的 x 记作 x_1，再加一个变量 x_2，令第 i 项是

$$f_i(x_1, x_2) = \frac{a_i}{2}(x_1 - b_i)^2 + \frac{1}{2}(x_2 - c_i)^2, \qquad (c_1, c_2, c_3) = (-1, 0, 1).$$

在 $(2, 1)$ 处，第一块的三个偏导是 $5, 4, -3$，平均 2；第二块的三个偏导是 $2, 1, 0$，平均 1。

固定历史后的核对 分两层取条件期望。先固定历史和选中的块 j，只对目标项求平均，由式 (13.3)得到

$$\mathbb{E}\big[\nabla_j f_{i^{(t)}}(\boldsymbol{x}^{(t)}) \mid \mathcal{F}^{(t)}, j\big] = \nabla_j f(\boldsymbol{x}^{(t)}).$$

所以给定块之后读数对这一块的偏梯度无偏，条件方差记为 σ_j^2。这一条要求选项的抽样分布不依赖于这一步的读数。若先把各块的读数算出来，再选读数最大的块，结果就有偏。

对选中的块使用块光滑常数 L_j，第 12章的块下降引理给出的单步界与式 (13.19)同样推导：

$$\begin{aligned}\mathbb{E}[f(\boldsymbol{x}^{(t+1)}) \mid \mathcal{F}^{(t)}, j] \le f(\boldsymbol{x}^{(t)}) - \alpha_j\Big(1 - \frac{L_j \alpha_j}{2}\Big)\|\nabla_j f(\boldsymbol{x}^{(t)})\|_2^2 \\ + \frac{L_j \alpha_j^2}{2}\sigma_j^2.\end{aligned} \tag{13.34}$$

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.3.1 小批量与梯度累积
13.3.2 非均匀抽样
13.3.3 SVRG
13.3.4 SAGA
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

两类随机性并存时 再对块的选择求平均。取块均匀，$\alpha_j = 1/L_j$，由式 (13.34)，

$$\mathbb{E}[f(\boldsymbol{x}^{(t+1)}) \mid \mathcal{F}^{(t)}] \le f(\boldsymbol{x}^{(t)}) - \frac{1}{J}\sum_{j=1}^{J} \frac{\|\nabla_j f(\boldsymbol{x}^{(t)})\|_2^2}{2L_j} + \frac{1}{J}\sum_{j=1}^{J} \frac{\sigma_j^2}{2L_j}.$$

只随机选块时 $\sigma_j = 0$，退回第 12章的结论，读取一行的成本是 N 项对这一块的偏导。同时抽样时，一次更新只读一格，代价小得多，但多出噪声项，邻域和步长都要像上面那样处理。

步长也要按两种随机性分别考虑：块步长 α_j 由块光滑常数决定，抽样噪声则要求更小的步长或方差控制。一个容易犯的错误是把噪声项算成所有块的方差之和，而每次其实只读一块；另一个错误是只对选项取期望，忘记选块也是随机的。例中在 $(2,1)$ 处，选块均匀、$\alpha_j = 0.1$ 时，平均更新量是

$$-\frac{1}{2}\cdot 0.1 \cdot (2,1) = (-0.1, -0.05).$$

这是两层平均的结果：选中第一块时第一个分量的平均更新是 -0.2，第二个分量不变，第二块反过来。一次实际抽样中，比如选第一块、第三项，更新量是 $(+0.3, 0)$，这与平均方向相反，与第 13.1.3小节的单项读数相反的情形相同。

13.3 方差控制

上一节的误差界都有一项与噪声方差 σ^2 成正比。目标和精度要求固定时，把这一项压下去就能用更少的更新达到相同的结果。有哪些办法减小读数的方差，每种办法又要付出多少读取、存储和维护成本？这两件事必须一起看，方差减小不等于总计算减少。

三类办法依次是：一次多读几项，改变抽项的分布，利用已经读过的梯度。

13.3.1 小批量与梯度累积

批量平均的方差 最直接的办法是一次读 B 项取平均。设给定历史后 $\hat{\boldsymbol{g}}_1, \dots, \hat{\boldsymbol{g}}_B$ 独立同分布，且都是 $\nabla f(\boldsymbol{x})$ 的无偏读数，条件方差为 σ^2。小批量（mini-batch）读数是

$$\hat{\boldsymbol{g}}_{(B)} = \frac{1}{B}\sum_{k=1}^{B} \hat{\boldsymbol{g}}_k. \tag{13.35}$$

记 $\boldsymbol{\zeta}_k = \hat{\boldsymbol{g}}_k - \nabla f(\boldsymbol{x})$。把平方展开，分成平方项和交叉项：

$$\mathbb{E}\Big[\Big\|\frac{1}{B}\sum_{k}\boldsymbol{\zeta}_k\Big\|_2^2 \;\Big|\; \mathcal{F}^{(t)}\Big] = \frac{1}{B^2}\sum_{k}\mathbb{E}[\|\boldsymbol{\zeta}_k\|_2^2 \mid \mathcal{F}^{(t)}] + \frac{1}{B^2}\sum_{k\neq l}\mathbb{E}[\langle \boldsymbol{\zeta}_k, \boldsymbol{\zeta}_l\rangle \mid \mathcal{F}^{(t)}].$$

给定历史时 $\boldsymbol{\zeta}_k$ 和 $\boldsymbol{\zeta}_l$ 独立且条件均值为零，所以内积的条件期望等于两个条件均值的内积，即零。平方项一共 B 个，所以

$$\operatorname{Var}\big[\hat{\boldsymbol{g}}_{(B)} \mid \mathcal{F}^{(t)}\big] = \frac{\sigma^2}{B}. \tag{13.36}$$

关键在于交叉项消失，这是独立带来的。若读数之间相关，交叉项不再为零，须把它们的协方差保留在展开式中。

无放回的方差　从 N 项中无放回地抽 B 项，读数不独立，交叉项有确定的值。记 $\boldsymbol{v}_i = \nabla f_i(\boldsymbol{x}) - \nabla f(\boldsymbol{x})$，它们的和是零，平均平方是 σ^2。对 $\|\sum_i \boldsymbol{v}_i\|_2^2 = 0$ 展开，得到

$$\sum_{i}\|\boldsymbol{v}_i\|_2^2 + \sum_{i\neq j}\langle \boldsymbol{v}_i, \boldsymbol{v}_j\rangle = 0.$$

所以不同的两项的内积平均是 $-\sigma^2/(N-1)$。

把这个值代入上面的展开式，交叉项一共 $B(B-1)$ 个，得到

$$\operatorname{Var}\big[\hat{\boldsymbol{g}}_{(B)} \mid \mathcal{F}^{(t)}\big] = \frac{\sigma^2}{B}\cdot\frac{N-B}{N-1}. \tag{13.37}$$

因子 $(N-B)/(N-1)$ 小于 1。$B = N$ 时方差为零，正是读完全部的情形。

在三项目标的 $x^\star$ 处核对，这时 $\sigma^2 = 56/3$，读数 $(4, 2, -6)$ 的和是零。取 $B = 2$ 无放回，三种配对的平均读数是 $3, -1, -2$，平方的平均是

$$\frac{9+1+4}{3} = \frac{14}{3}.$$

公式 (13.37)给出同一结果：$\frac{56/3}{2}\cdot\frac{1}{2} = \frac{14}{3}$。有放回的 $B = 2$ 则是 $28/3$，多了一倍。

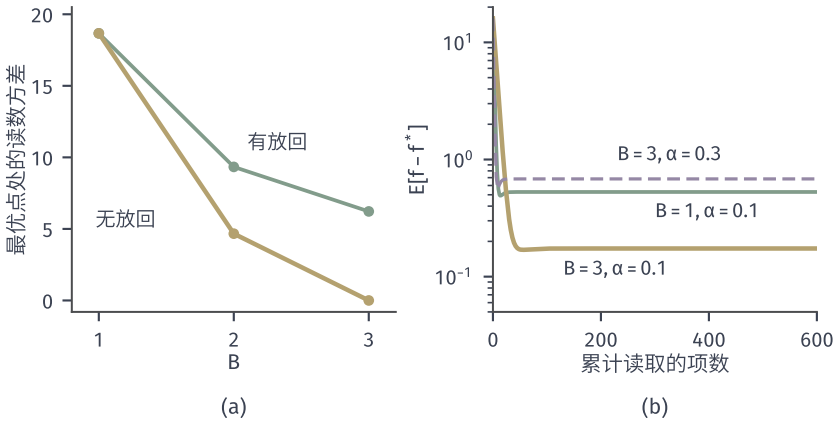


图 13.14 小批量的方差与成本，三项目标。(a) 最优点处读数方差随批量的变化，绿线有放回，黄线无放回，$B = 3$ 时无放回的方差为零。(b) 从 $x^{(0)} = 5$ 出发的期望目标差，由精确递推算出，横轴是累计读取的项数。绿线 $B = 1$，黄线 $B = 3$ 且步长相同，紫色虚线 $B = 3$ 且步长乘以 3。

方差减小不等于计算减少 式 (13.36)让噪声项除以 B，但读取量乘以 B。图 13.14(b) 说明了两者的权衡。步长不变时，$B = 3$ 的噪声底从 0.53 降到 0.17；把步长也放大 3 倍，保持每次读取走过的距离不变，$B = 3$ 的噪声底是 0.68，并不比 $B = 1$ 更好，初始阶段的下降也差不多。在步长可以随批量调整的范围内，增加批量和缩小步长的效果大体相同，总读取量并没有节省。

增加批量的价值在别处：多个读数可以并行计算，矩阵运算可以成批进行，方差小了也允许使用更稳健的步长。这些是实现上的收益，须按实际硬件单独计算。

梯度累积 批量太大、一次放不进内存时，可以把它拆成若干微批量，分别算梯度后加起来，只更新一次，这称为**梯度累积**（gradient accumulation）。设批量 B 拆成微批量，大小为 $n_1, \dots, n_K$，$\sum_k n_k = B$。设第 k 个微批量的平均读数为 $\hat{\boldsymbol{g}}_k$，累积时必须按样本数加权：

$$\hat{\boldsymbol{g}}_{(B)} = \sum_{k=1}^{K} \frac{n_k}{B} \hat{\boldsymbol{g}}_k . \tag{13.38}$$

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.3.1 小批量与梯度累积
13.3.2 非均匀抽样
13.3.3 SVRG
13.3.4 SAGA
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

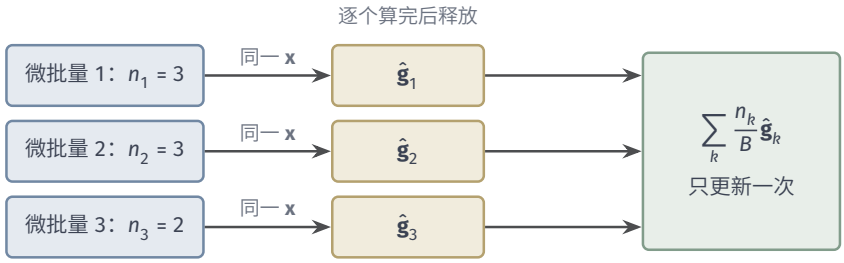


图 13.15　梯度累积。批量 8 拆成大小为 3, 3, 2 的微批量。参数在整个过程中保持不变，每个微批量的梯度算完就可以释放它占用的样本与中间结果。累积时按 n_k/B 加权，全部读完后才更新一次。

图 13.15显示了三个要求。第一，整个累积过程中参数 $\boldsymbol{x}$ 不变，否则各微批量的梯度算在不同的点上，加起来不是一个点的梯度。第二，目标函数不变，包括确定的正则项只加一次。第三，权重按样本数计。三项目标上把第一、二项作为一个微批量，第三项单独作为一个，$x = 2$ 处

$$\frac{2}{3}\cdot\frac{5+4}{2}+\frac{1}{3}\cdot(-3)=2,$$

与三项的平均相同。若不加权，直接平均两个微批量的读数，得到 $(4.5-3)/2 = 0.75$，答案错了。

读数若还依赖批内统计量，例如用批内均值做归一化，拆开后微批量的统计量与整批不同，累积结果不再等于整批的结果，这些统计量要在整批范围内统一更新。

梯度累积减少的只是同时占用的存储，总读取量仍是 B。它不是一种降低方差的新办法，只是用更长的时间换更少的内存，方差与整批相同。

13.3.2 非均匀抽样

有些项的梯度大，有些小。均匀抽样对所有项一视同仁，把更多机会给“重要”的项，能否减小方差？

逆概率权重　以固定的正概率 $p_1,\dots,p_N$ 抽项，$\sum_i p_i = 1$。为使条件均值仍是完整梯度，要给读数加上逆概率权重：

$$\hat{\boldsymbol{g}} = \frac{1}{Np_i}\nabla f_i(\boldsymbol{x}) + \nabla r(\boldsymbol{x}). \tag{13.39}$$

确定的正则梯度 ∇r 无需抽样，单独加入。条件均值按概率加权直接计算，分母上的 p_i 与概率相消：

$$\sum_{i=1}^{N} p_i\cdot\frac{1}{Np_i}\nabla f_i(\boldsymbol{x}) + \nabla r(\boldsymbol{x}) = \frac{1}{N}\sum_{i=1}^{N}\nabla f_i(\boldsymbol{x}) + \nabla r(\boldsymbol{x}).$$

这就是式 (13.7)的完整梯度。这种做法称为**非均匀抽样**（non-uniform sampling），权重也称重要性权重。

权重不能省略。第 13.1.3小节的概率 $(1/2, 1/4, 1/4)$ 在不加权时，实际被最小化的是加权目标 $\frac{1}{2}f_1 + \frac{1}{4}f_2 + \frac{1}{4}f_3$，它的梯度是

$$\frac{1}{2}(x+3) + \frac{1}{4}\cdot 2x + \frac{1}{4}(3x-9) = \frac{7}{4}x - \frac{3}{4}.$$

零点是 $x = 3/7$，而不是 $x^\star = 1$。算法的不动点取决于读数的条件均值，而不取决于更新的形式。

不同概率下的二阶矩　无偏之后比较方差，只需比较二阶矩，因为均值已固定。设 $r = 0$，读数 $\frac{1}{Np_i}\nabla f_i$ 的二阶矩是

$$M(\boldsymbol{p}) = \sum_{i=1}^{N} p_i \left\| \frac{\nabla f_i(\boldsymbol{x})}{N p_i} \right\|_2^2 = \frac{1}{N^2}\sum_{i=1}^{N} \frac{\|\nabla f_i(\boldsymbol{x})\|_2^2}{p_i}. \tag{13.40}$$

由 Cauchy–Schwarz 不等式，

$$\Big(\sum_i \|\nabla f_i\|_2\Big)^2 \le \Big(\sum_i \frac{\|\nabla f_i\|_2^2}{p_i}\Big)\Big(\sum_i p_i\Big).$$

于是 $M(\boldsymbol{p})$ 的最小值是 $(\sum_i \|\nabla f_i\|_2)^2/N^2$，在 $p_i \propto \|\nabla f_i(\boldsymbol{x})\|_2$ 时取到。最优概率依赖当前点，而算出它需要读完全部的项，这与抽样的目的相矛盾。

在三项目标的 $x^\star$ 处，读数是 $(4, 2, -6)$，代入式 (13.40)比较三种概率：

$$\begin{aligned}
\boldsymbol{p} = \big(\tfrac{1}{3},\tfrac{1}{3},\tfrac{1}{3}\big): &\quad M = \tfrac{56}{3} \approx 18.67,\\
\boldsymbol{p} \propto (L_1,L_2,L_3) = \big(\tfrac{1}{6},\tfrac{1}{3},\tfrac{1}{2}\big): &\quad M = 20,\\
\boldsymbol{p} \propto (|4|,|2|,|-6|) = \big(\tfrac{1}{3},\tfrac{1}{6},\tfrac{1}{2}\big): &\quad M = 16.
\end{aligned}$$

常用的 $p_i \propto L_i$ 在这个点上比均匀更差。这种选择有另外的好处：加权后各项的光滑常数 $L_i/(Np_i)$ 相同，都等于 $\bar{L} = \frac{1}{N}\sum_i L_i = 2$，而不再是 $L_{\max} = 3$。依赖逐项光滑常数的步长上界因此放宽。

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.3.1 小批量与梯度累积
13.3.2 非均匀抽样
13.3.3 SVRG
13.3.4 SAGA
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

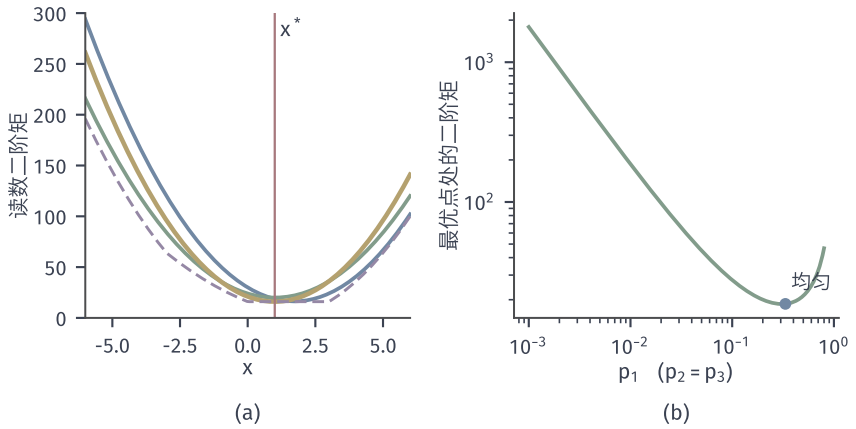


图 13.16 非均匀抽样的二阶矩，三项目标。(a) 不同固定概率下的读数二阶矩随 x 的变化：蓝线均匀，绿线 $p_i \propto L_i$，黄线 $p_i \propto |f_i'(x^\star)|$，紫色虚线是每点都用最优概率的下包络，红线是 $x^\star$。(b) 最优点处二阶矩随 p_1 的变化，$p_2 = p_3 = (1-p_1)/2$，两轴取对数，蓝点是均匀抽样。

图 13.16(a) 显示，三条曲线在不同位置各有胜负。没有哪个固定的分布处处最好，这是最优概率依赖 $\boldsymbol{x}$ 的直接表现。图 (b) 说明另一个危险：概率过小会放大读数。$p_1 = 0.01$ 时第一项读数被放大 $1/(3 \cdot 0.01) \approx 33$ 倍，$x^\star$ 处的二阶矩升到约 187，是均匀抽样的十倍。一项只要可能有非零梯度，就要给它不太小的概率。

代价方面要算三笔账。计算概率需要各项的 L_i 或梯度范数的估计；维护离散分布、每次抽样需要合适的数据结构，概率更新后还要维护；若各项尺度相近，这些投入得不到回报。只有各项差异明显、概率容易得到时，非均匀抽样才值得使用。

13.3.3 SVRG

小批量靠多读减小方差，方差只能按 $1/B$ 下降，到最优点也不消失。有没有办法让读数的方差随迭代点靠近解而自动趋于零？图 13.1(b) 的观察给出了线索：三条单项导数虽然不同，但都是光滑变化的，在相邻两点的差别不大。

主要思想 控制变量的想法是：如果要估计一个数，手里还有一个与它高度相关且均值已知的量，就可以用它来纠偏。这里的已知量是一个旧点的梯度。

选一个快照点 $\tilde{\boldsymbol{x}}$，事先计算好它的完整梯度 $\nabla f(\tilde{\boldsymbol{x}})$。此后每一步抽 i，用同一项在当前点和快照点的梯度差，加上快照的完整梯度：

$$\hat{\boldsymbol{g}} = \nabla f_i(\boldsymbol{x}) - \nabla f_i(\tilde{\boldsymbol{x}}) + \nabla f(\tilde{\boldsymbol{x}}). \tag{13.41}$$

这就是SVRG（stochastic variance reduced gradient）[2]。的方向。$\nabla f_i(\tilde{\boldsymbol{x}})$ 称为**控制变量**（control variate）。

对 i 求条件平均，第一项是 $\nabla f(\boldsymbol{x})$，后两项相消：

$$\mathbb{E}[\hat{\boldsymbol{g}} \mid \mathcal{F}^{(t)}] = \nabla f(\boldsymbol{x}) - \nabla f(\tilde{\boldsymbol{x}}) + \nabla f(\tilde{\boldsymbol{x}}) = \nabla f(\boldsymbol{x}).$$

所以 $\hat{\boldsymbol{g}}$ 条件无偏，这里不需要任何关于 $\tilde{\boldsymbol{x}}$ 的假设。方差却取决于 $\boldsymbol{x}$ 和 $\tilde{\boldsymbol{x}}$ 的距离：若 $\boldsymbol{x} = \tilde{\boldsymbol{x}}$，$\hat{\boldsymbol{g}}$ 恰为完整梯度，一点噪声也没有。

三项目标的读数是一次函数，修正后的方向很简单：

$$\hat{g} = a_i(x - \tilde{x}) + f'(\tilde{x}).$$

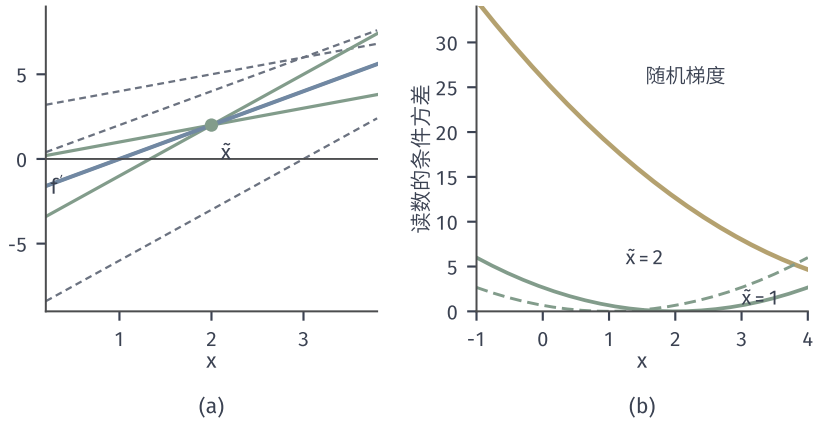


图 13.17 SVRG 的纠偏，三项目标，快照 $\tilde{x} = 2$。(a) 虚线是原始的三项读数，绿线是修正后的读数，蓝线是 f'。修正后的三条线都经过快照处的点 $(2, f'(2))$。(b) 读数的条件方差随 x 的变化：黄线是普通随机梯度，绿实线是快照 $\tilde{x} = 2$，绿虚线是快照 $\tilde{x} = 1 = x^\star$。

图 13.17(a) 说明了修正的几何含义：原始的三条读数线各自散开，修正后都绕着快照处的完整梯度旋转，x 越接近快照，分散越小。条件方差的表达式是 $\frac{2}{3}(x - \tilde{x})^2$，它在 $x = \tilde{x}$ 处为零，这正是图 (b) 的绿线。比较 $x = 1$ 这一点，快照 $\tilde{x} = 2$ 时条件方差是 $2/3$，普通随机梯度是 $56/3$。

快照要不断更新。随着 $\boldsymbol{x}$ 收敛，把快照移过来，图 (b) 的绿线就从实线变成虚线，方差在解处变成零。这样，算法每隔若干步要花一次完整梯度的成本重新设置快照，因此有内外两层循环，如图 13.18所示。

[2] R. Johnson, T. Zhang, *Accelerating Stochastic Gradient Descent using Predictive Variance Reduction* In Advances in Neural Information Processing Systems, 2013, pp. 315–323

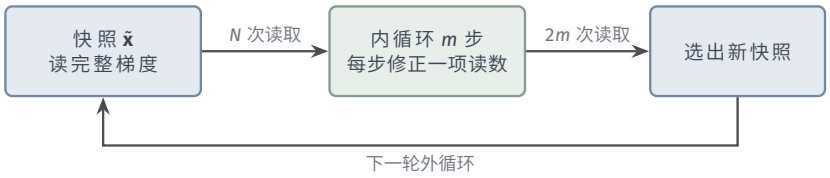


图 13.18　SVRG 的两层循环。外循环计算完整梯度（N 次读取）并存下快照，内循环运行 m 步，每步用式 (13.41)，读取同一项在两点的梯度（2 次读取）。一轮外循环共 $N+2m$ 次读取。

变量

- $\tilde{\boldsymbol{x}} \in \mathbb{R}^n$：快照点。
- $\tilde{\boldsymbol{g}} \in \mathbb{R}^n$：快照点的完整梯度 $\nabla f(\tilde{\boldsymbol{x}})$。
- $\boldsymbol{x}^{(t)} \in \mathbb{R}^n$：内循环的当前点，$t = 0, \dots, m$。
- $\alpha > 0$，m：步长和内循环长度。

初始化　取初始快照 $\tilde{\boldsymbol{x}}$。例中取 $\tilde{x} = 2$，$\alpha = 0.05$，这满足后面定理的条件，由式 (13.6)，

$$\tilde{g} = f'(2) = 2.$$

每轮更新　外循环的一轮按下列步骤进行。

1. 快照：置 $\boldsymbol{x}^{(0)} = \tilde{\boldsymbol{x}}$，计算 $\tilde{\boldsymbol{g}} = \nabla f(\tilde{\boldsymbol{x}})$，共 N 次读取。例中 $x^{(0)} = 2$，$\tilde{g} = 2$。
2. 内循环：对 $t = 0, \dots, m-1$，抽下标 $i^{(t)}$，按式 (13.41)得到方向 $\hat{\boldsymbol{g}}^{(t)}$，沿它走步长 α 得到新点。

   例中第一步抽到 $i = 3$，$x^{(0)} = \tilde{x}$，方向就是完整梯度，

   $$\hat{g}^{(0)} = 2, \qquad x^{(1)} = 2 - 0.05 \cdot 2 = 1.9.$$

   第二步抽到 $i = 1$，$a_1 = 1$，方向和新点是

   $$\hat{g}^{(1)} = 1 \cdot (1.9 - 2) + 2 = 1.9, \qquad x^{(2)} = 1.9 - 0.05 \cdot 1.9 = 1.805.$$

   第三步抽到 $i = 2$，$a_2 = 2$，方向和新点是

   $$\hat{g}^{(2)} = 2 \cdot (1.805 - 2) + 2 = 1.61, \qquad x^{(3)} = 1.805 - 0.05 \cdot 1.61 = 1.7245.$$

3. 选取新快照：从内循环的点中选一个作为新的 $\tilde{\boldsymbol{x}}$。下面的定理要求在 $\boldsymbol{x}^{(0)}, \dots, \boldsymbol{x}^{(m-1)}$ 中均匀随机选取，实践中也常取最后一点。

外循环达到预定轮数后结束。最终得到最后一次的快照。例中三步都朝 $x^\star = 1$ 靠近，方向全部为正，没有再出现单项读数 -3 带来的上坡，这正是控制变量的效果。

差分的方差与收敛 证明方差自动减小的关键，是用目标差控制逐项梯度的差。需要假设每一项都是光滑的凸函数。

引理 13.9 逐项梯度差的控制 设 f_i 凸且梯度 L-Lipschitz，$f = \frac{1}{N}\sum_i f_i$ 有最小点 $\boldsymbol{x}^\star$。则对任意 $\boldsymbol{x}$，

$$\frac{1}{N}\sum_{i=1}^{N}\|\nabla f_i(\boldsymbol{x}) - \nabla f_i(\boldsymbol{x}^\star)\|_2^2 \le 2L\big(f(\boldsymbol{x}) - f^\star\big). \tag{13.42}$$

证明 定义

$$\psi_i(\boldsymbol{x}) = f_i(\boldsymbol{x}) - f_i(\boldsymbol{x}^\star) - \langle \nabla f_i(\boldsymbol{x}^\star), \boldsymbol{x} - \boldsymbol{x}^\star\rangle.$$

ψ_i 凸，梯度 L-Lipschitz，$\nabla\psi_i(\boldsymbol{x}^\star) = \boldsymbol{0}$，所以 $\boldsymbol{x}^\star$ 是它的最小点，最小值为 0。

对 ψ_i 从 $\boldsymbol{x}$ 走一步 $\boldsymbol{x} - \nabla\psi_i(\boldsymbol{x})/L$，由下降引理，

$$0 \le \psi_i\Big(\boldsymbol{x} - \frac{1}{L}\nabla\psi_i(\boldsymbol{x})\Big) \le \psi_i(\boldsymbol{x}) - \frac{1}{2L}\|\nabla\psi_i(\boldsymbol{x})\|_2^2.$$

$\nabla\psi_i(\boldsymbol{x})$ 就是 $\nabla f_i(\boldsymbol{x})$ 与 $\nabla f_i(\boldsymbol{x}^\star)$ 的差。对 i 平均时，由 $\nabla f(\boldsymbol{x}^\star) = \boldsymbol{0}$，一次项消失，$\psi_i$ 的平均恰为 $f(\boldsymbol{x}) - f^\star$。整理即得式 (13.42)。 ■

定理 13.10 SVRG 的线性收缩 设每个 f_i 凸且梯度 L-Lipschitz，f 是 μ 强凸的。设 $0 < \alpha < 1/(4L)$，m 足够大，使

$$\rho = \frac{1}{\mu\alpha(1 - 2L\alpha)m} + \frac{2L\alpha}{1 - 2L\alpha} < 1. \tag{13.43}$$

每轮外循环的新快照在 $\boldsymbol{x}^{(0)}, \dots, \boldsymbol{x}^{(m-1)}$ 中均匀随机选取。则相邻两轮的快照 $\tilde{\boldsymbol{x}}_s$，$\tilde{\boldsymbol{x}}_{s+1}$ 满足

$$\mathbb{E}[f(\tilde{\boldsymbol{x}}_{s+1})] - f^\star \le \rho\big(\mathbb{E}[f(\tilde{\boldsymbol{x}}_s)] - f^\star\big). \tag{13.44}$$

证明 固定一轮外循环，$\tilde{\boldsymbol{x}}$ 由此前的历史确定。记 $\boldsymbol{x}=\boldsymbol{x}^{(t)}$，$E_x=f(\boldsymbol{x})-f^\star$，$E_s=f(\tilde{\boldsymbol{x}})-f^\star$。先控制方向的二阶矩。

在方向 (13.41)中加减 $\nabla f_i(\boldsymbol{x}^\star)$，把它写成两段之和，再用不等式 $(a+b)^2\le 2a^2+2b^2$，得到

$$\|\hat{\boldsymbol{g}}\|_2^2 \le 2\|\nabla f_i(\boldsymbol{x})-\nabla f_i(\boldsymbol{x}^\star)\|_2^2+2\|\nabla f_i(\tilde{\boldsymbol{x}})-\nabla f_i(\boldsymbol{x}^\star)-\nabla f(\tilde{\boldsymbol{x}})\|_2^2.$$

第二段里，$\nabla f_i(\tilde{\boldsymbol{x}})-\nabla f_i(\boldsymbol{x}^\star)$ 的条件均值恰为 $\nabla f(\tilde{\boldsymbol{x}})$，第二段就是它减去自己的均值。方差不超过二阶矩，所以去掉 $\nabla f(\tilde{\boldsymbol{x}})$ 后条件期望不会变小。对两段分别用式 (13.42)，得到

$$\mathbb{E}\big[\|\hat{\boldsymbol{g}}\|_2^2 \mid \mathcal{F}^{(t)}\big] \le 4L(E_x+E_s).$$

再展开距离。由条件无偏和 f 的凸性，内积项不小于 E_x，于是

$$\mathbb{E}\big[\|\boldsymbol{x}^{(t+1)}-\boldsymbol{x}^\star\|_2^2 \mid \mathcal{F}^{(t)}\big] \le \|\boldsymbol{x}-\boldsymbol{x}^\star\|_2^2-2\alpha E_x+4L\alpha^2(E_x+E_s).$$

对 $t=0,\dots,m-1$ 求和取全期望，距离项相消，并丢掉非负的终点距离。记 $\bar{E}$ 为内循环点目标差的平均，它也是随机选出的新快照的期望目标差，得到

$$2\alpha(1-2L\alpha)m\bar{E} \le \mathbb{E}\|\tilde{\boldsymbol{x}}-\boldsymbol{x}^\star\|_2^2+4L\alpha^2 m\,\mathbb{E}[E_s].$$

强凸性给出快照点的距离上界 $\frac{2}{\mu}E_s$，代入后得到

$$2\alpha(1-2L\alpha)m\bar{E} \le \Big(\frac{2}{\mu}+4L\alpha^2 m\Big)\mathbb{E}[E_s].$$

两边除以 $2\alpha(1-2L\alpha)m$，即得式 (13.44)。 ∎

式 (13.43)的两项分别表示：内循环够长，初始距离的影响才能被摊薄；步长够小，快照带来的方差项才小于收缩。这里 L 是单项的光滑常数，在三项目标上 $L=3$，$\mu=2$。取 $\alpha=0.05<1/12$，$m=50$，得到

$$\rho=\frac{1}{2\cdot 0.05\cdot 0.7\cdot 50}+\frac{0.3}{0.7}\approx 0.286+0.429=0.714.$$

这是一个保守的上界。三项目标从 $\tilde{x}=2$ 开始一轮的实际结果，用 20000 次独立运行的平均来估计，目标差约从 1 降到 0.115。

成本 一轮外循环需要 $N+2m$ 次读取，每轮把目标差减小一个固定比例。取 α 为 $1/L$ 的小常数倍、m 与 κ 同量级时 ρ 是小于 1 的常数，所以减小一

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.3.1 小批量与梯度累积
13.3.2 非均匀抽样
13.3.3 SVRG
13.3.4 SAGA
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

个固定比例约需 $N+\kappa$ 量级的读取，这里 $\kappa = L/\mu$ 用单项的光滑常数计算。完整梯度下降减小同样的比例约需 $N\kappa_f$ 量级的读取，其中 κ_f 用 f 本身的光滑常数计算。N 很大时前者优势明显。存储上，SVRG 只保存 $\tilde{\boldsymbol{x}}$ 和 $\tilde{\boldsymbol{g}}$ 两个向量，每步重新计算 $\nabla f_i(\tilde{\boldsymbol{x}})$。也可以事先保存所有项的快照梯度，每步只需一次读取，但内存要多 N 个向量。内循环长度 m、快照的频率，在理论和实践之间常有差别，定理的 m 往往偏大。

SVRG 要求能重复访问所有项，且每轮要算一次完整梯度，所以只适用于有限和目标；样本源源不断的期望目标不能直接用。

13.3.4 SAGA

SVRG 要定期花一次完整梯度来设置快照。如果把每一项上次读到的梯度都记下来，是不是不用专门做快照，靠记忆逐步更新就够了？这就是 SAGA[3]。的想法。

[3] A. Defazio, F. Bach, S. Lacoste-Julien, *SAGA: A Fast Incremental Gradient Method With Support for Non-Strongly Convex Composite Objectives* In Advances in Neural Information Processing Systems, 2014, pp. 1646–1654

主要思想 为每一项维护一个存下的旧梯度 $\boldsymbol{\phi}_i$，以及它们的均值 $\bar{\boldsymbol{\phi}} = \frac{1}{N}\sum_i \boldsymbol{\phi}_i$。每一步抽 i，用新读数减去这一项的旧读数，再加上旧均值：

$$\hat{\boldsymbol{g}} = \nabla f_i(\boldsymbol{x}) - \boldsymbol{\phi}_i + \bar{\boldsymbol{\phi}}. \tag{13.45}$$

这与 SVRG 的方向形式相同，只是把快照点的梯度换成了各项自己记录的旧梯度。给定历史，表项都是确定的，对 i 求条件平均，第二、三项相消，所以方向条件无偏。

完成参数更新之后，才把表项 $\boldsymbol{\phi}_i$ 替换成新读数，并同步修改均值：

$$\bar{\boldsymbol{\phi}} \leftarrow \bar{\boldsymbol{\phi}} + \frac{1}{N}\left(\nabla f_i(\boldsymbol{x}) - \boldsymbol{\phi}_i\right). \tag{13.46}$$

这个次序不能交换。若先把 $\boldsymbol{\phi}_i$ 换成新读数，方向就变成 $\bar{\boldsymbol{\phi}}$，只是旧梯度的平均，新读数根本没有进入更新，条件无偏也失去了。

变量

- $\boldsymbol{x}^{(t)} \in \mathbb{R}^n$：当前点。
- $\boldsymbol{\phi}_i \in \mathbb{R}^n$，$i = 1, \dots, N$：各项记录的旧梯度，共 N 个向量。
- $\bar{\boldsymbol{\phi}} \in \mathbb{R}^n$：表项的均值，用式 (13.46)增量更新，不必每次重算。
- $\alpha > 0$：步长。

初始化 在初始点读全部 N 项填满梯度表，N 次读取。例中取 $x^{(0)} = 2$，$\alpha = 0.05$，表项和均值是

$$(\phi_1, \phi_2, \phi_3) = (5, 4, -3), \qquad \bar{\phi} = 2.$$

每轮更新 对 $t = 0, 1, \dots$ 依次执行以下步骤。

1. 抽样并读取：抽 $i^{(t)}$，计算新读数 $\nabla f_{i^{(t)}}(\boldsymbol{x}^{(t)})$，这是一次读取。例中第一轮抽到 $i = 3$，新读数是 -3。
2. 计算方向并更新：由式 (13.45)，例中第一轮

$$\hat{g}^{(0)} = -3 - (-3) + 2 = 2, \qquad x^{(1)} = 2 - 0.05 \cdot 2 = 1.9.$$

3. 更新表项：把 $\boldsymbol{\phi}_{i^{(t)}}$ 换成新读数，按式 (13.46)修改均值。例中第一轮新读数与旧表项相同，ϕ_3 和均值都不变。

   例中第二轮抽到 $i = 1$，新读数 $f_1'(1.9) = 4.9$，方向和新点是

$$\hat{g}^{(1)} = 4.9 - 5 + 2 = 1.9, \qquad x^{(2)} = 1.9 - 0.05 \cdot 1.9 = 1.805.$$

然后 ϕ_1 变成 4.9，均值变成 $(4.9 + 4 - 3)/3 \approx 1.967$。

例中第三轮抽到 $i = 2$，新读数 $f_2'(1.805) = 3.61$，方向和新点是

$$\hat{g}^{(2)} \approx 3.61 - 4 + 1.967 = 1.577, \qquad x^{(3)} \approx 1.805 - 0.05 \cdot 1.577 = 1.726.$$

然后 ϕ_2 变成 3.61，均值变成 $(4.9 + 3.61 - 3)/3 \approx 1.837$。图 13.19画出了表的变化。

	ϕ_1	ϕ_2	ϕ_3	均值
初始	5	4	−3	2
$t=0,\ i=3$	5	4	−3	2
$t=1,\ i=1$	4.9	4	−3	1.967
$t=2,\ i=2$	4.9	3.61	−3	1.837

图 13.19 SAGA 的梯度表在三步内的变化。每行是完成该步之后的表，黄框是刚被替换的项，右列是表的均值。第一步新读数恰好等于旧表项，表不变；此后只有被抽到的项发生变化。

迭代在读取量达到预定预算后结束，最终得到 $\boldsymbol{x}^{(T)}$；例中三步后 $x^{(3)} \approx 1.726$，每步一次读取，加上初始化的三次，共六次读取。

两种误差共同评价 SAGA 的状态比普通方法多一张表，所以进展要同时看两件事：参数离解多远，表项离各自的 $\nabla f_i(\boldsymbol{x}^\star)$ 多远。参数接近解之后，表项还可能很旧，方差还不会小。要让方差趋于零，就需要每一项都被更新到解附近。

定理 13.11 SAGA 的线性收敛 设每个 f_i 凸且梯度 L-Lipschitz，f 是 μ 强凸的，取 $\alpha = 1/(3L)$，下标独立均匀抽取，梯度表在初始点填满。则存在只依赖初始距离和初始表项误差的常数 C，使

$$\mathbb{E}[\|\boldsymbol{x}^{(T)} - \boldsymbol{x}^\star\|_2^2] \le \left(1 - \min\left\{\frac{1}{4N}, \frac{\mu}{3L}\right\}\right)^T C. \tag{13.47}$$

式 (13.47)的证明需要构造一个同时包含距离和各表项误差的函数，并证明它的期望按上述比例收缩，推导较长，读者可查阅原始论文[4]。这里解释结论的机制。速率的最小值中有两项：$\mu/(3L)$ 与单纯的梯度下降类似，由条件数决定；$1/(4N)$ 反映表项的刷新速度，每一步只刷新一项，刷新一遍大约需要 N 步。N 很大时，记忆更新是瓶颈，反过来则是条件数决定收敛。

[4] A. Defazio, F. Bach, S. Lacoste-Julien, *SAGA: A Fast Incremental Gradient Method With Support for Non-Strongly Convex Composite Objectives* In Advances in Neural Information Processing Systems, 2014, pp. 1646–1654

在三项目标上，$N=3$，$L=3$，$\mu=2$，所以

$$\min\left\{\frac{1}{12}, \frac{2}{9}\right\} = \frac{1}{12},$$

定理保证的是每步收缩 $11/12$。手算所用的 $\alpha = 0.05$ 小于 $1/(3L) = 1/9$，只用来演示表项的变化。

SAGA 没有强凸性时也有保证，平均点的目标差按 $1/T$ 的量级下降，常数与 N 有关，这里不再讨论。

比较 表 13.2按读取和存储比较这些方法。方差控制的共同代价是：多读或多存，并依赖逐项光滑、凸性等结构。

方法	每次更新读取	存储	需要重复访问
随机梯度	1	1 个向量	否
小批量	B	1 个向量	否
SVRG	2，另有每轮 N	2 个向量	是
SAGA	1，初始化 N	$N+2$ 个向量	是

表 13.2 方差控制方法的成本。存储只计迭代所需向量，随机梯度和小批量含当前点。

SAGA 的表要存 N 个 n 维向量，这在 N 和 n 都很大时是沉重的负担。对各项梯度是某个数乘已知向量的线性模型，每个表项只需存一个标量，才算切实可行。

图 13.20用一个 $N = 500$、$n = 20$ 的正则最小二乘实例比较总读取量。横轴是读取量除以 N，即完整遍历的轮数。随机梯度初期最快，但很快到达噪声底。完整梯度稳定下降，但每步代价是 N。SVRG 和 SAGA 在初期略慢于随机梯度，此后保持线性收敛，目标差继续下降到比噪声底小许多个量级的水平。

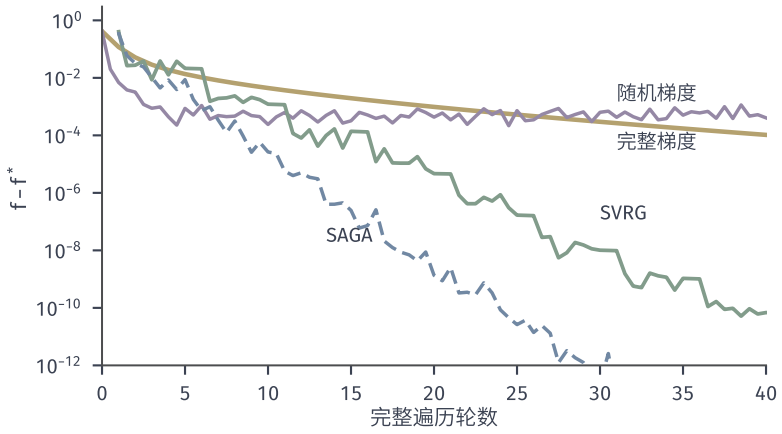


图 13.20 总读取量与目标差，$N = 500$、$n = 20$ 的正则最小二乘实例（种子固定），$\|\boldsymbol{a}_i\|_2 = 1$，$\gamma = 0.005$。黄线是完整梯度，紫线是固定步长 0.1 的随机梯度，绿线是 SVRG（$\alpha = 0.2/L$，$m = 2N$，此处 L 取单项的光滑常数），蓝色虚线是 SAGA（$\alpha = 1/(3L)$）。横轴是读取量除以 N，纵轴取对数。

这个比较的结论有边界：只针对这一个实例和这一组参数，SVRG 和 SAGA 的优势在需要高精度时才明显。若只需低精度，或者问题本身的噪声底已经够用，普通随机梯度加小批量更简单；若数据是流式的，不能重复访问，这两种方法都用不上。

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.4.1 随机重球法
13.4.2 随机 Nesterov 方法
13.4.3 Lion 符号动量（补充）
13.4.4 Muon 矩阵动量（补充）
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

13.4 随机动量方法

小批量和控制变量都在改善单步的读数，代价是多读梯度或多存梯度。本节换一个问题：不增加读取，只把已经读过的梯度组合进当前方向，能得到什么，又要付出什么？

组合历史读数有两种效果。一致的成分累积起来，随机涨落互相抵消，这是平滑；旧读数来自旧的位置，当前梯度变化时方向跟不上，这是滞后。两者同时发生，而且历史进入了算法的状态，每一步的误差要连同历史一起分析。本节先讲当前点读数的重球法，再讲前瞻点读数的 Nesterov 方法，最后讲两种把动量做非线性变换的方法。

13.4.1 随机重球法

主要思想 第 6章的重球法在当前梯度步之外，再加上一步历史位移。把其中的梯度换成当前点的随机读数 $\hat{\boldsymbol{g}}^{(t)}$，就得到**随机重球法**（stochastic heavy ball method）。规定 $\boldsymbol{x}^{(-1)}=\boldsymbol{x}^{(0)}$，

$$\boldsymbol{x}^{(t+1)}=\boldsymbol{x}^{(t)}-\alpha\hat{\boldsymbol{g}}^{(t)}+\beta\big(\boldsymbol{x}^{(t)}-\boldsymbol{x}^{(t-1)}\big),\qquad 0\le\beta<1. \tag{13.48}$$

式 (13.48)要存两个位置。实际计算常改写成只存一个速度向量 $\boldsymbol{v}^{(t)}$ 的形式：取 $\boldsymbol{v}^{(0)}=\boldsymbol{0}$，先更新速度，再更新位置，

$$\boldsymbol{v}^{(t+1)}=\beta\boldsymbol{v}^{(t)}+\hat{\boldsymbol{g}}^{(t)},\qquad \boldsymbol{x}^{(t+1)}=\boldsymbol{x}^{(t)}-\alpha\boldsymbol{v}^{(t+1)}. \tag{13.49}$$

两种写法等价。由速度形式，上一步的位移满足 $\boldsymbol{x}^{(t)}-\boldsymbol{x}^{(t-1)}=-\alpha\boldsymbol{v}^{(t)}$，于是

$$-\alpha\boldsymbol{v}^{(t+1)}=-\alpha\hat{\boldsymbol{g}}^{(t)}-\alpha\beta\boldsymbol{v}^{(t)}=-\alpha\hat{\boldsymbol{g}}^{(t)}+\beta\big(\boldsymbol{x}^{(t)}-\boldsymbol{x}^{(t-1)}\big).$$

还有第三种常见写法，把方向写成读数的移动平均。令 $\boldsymbol{m}^{(t)}=(1-\beta)\boldsymbol{v}^{(t)}$，式 (13.49)的速度递推两边乘以 $1-\beta$，得到

$$\boldsymbol{m}^{(t+1)}=\beta\boldsymbol{m}^{(t)}+(1-\beta)\hat{\boldsymbol{g}}^{(t)},\qquad \boldsymbol{x}^{(t+1)}=\boldsymbol{x}^{(t)}-\alpha'\boldsymbol{m}^{(t+1)}, \tag{13.50}$$

其中两种写法的步长的对应关系是

$$\alpha'=\frac{\alpha}{1-\beta}. \tag{13.51}$$

对应关系决定了调参的含义。在速度写法中固定 α 而增大 β，方向的总权重变大，$\alpha/(1-\beta)$ 随之变大，所以 $\alpha/(1-\beta)$ 称为**有效步长**（effective step size）。在移动平均写法中固定 α' 而增大 β，方向的总权重不变，只是平均的窗口更长。比较两种实现时，先把参数换到同一种写法。

历史权重：平滑与滞后 方向怎样由历史读数组成？反复代入速度递推，得到

$$\boldsymbol{v}^{(t+1)} = \sum_{s=0}^{t} \beta^{t-s} \hat{\boldsymbol{g}}^{(s)}. \tag{13.52}$$

一个 s 轮之前的读数，权重是 β^s，按等比衰减。移动平均写法中的权重是 $(1-\beta)\beta^s$，全部加起来等于 $1-\beta^{t+1}$，轮数足够多时接近 1。图 13.21(a) 画出两个 β 对应的权重：β 越接近 1，权重越平，记忆越长。

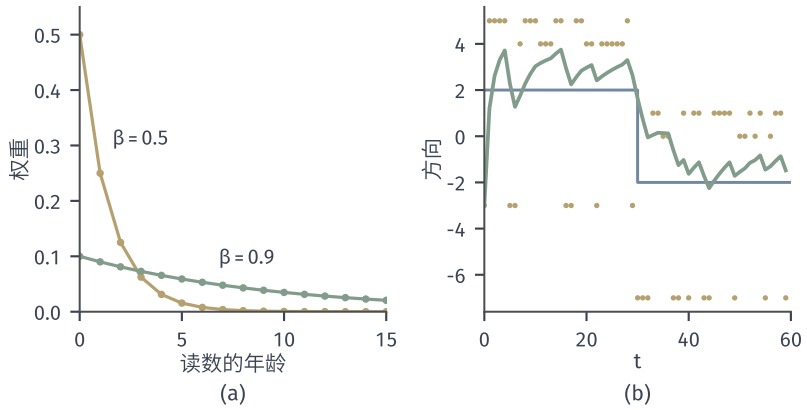


图 13.21 移动平均的平滑与滞后。(a) 读数按年龄的权重 $(1-\beta)\beta^s$，黄线 $\beta = 0.5$，绿线 $\beta = 0.9$。(b) 蓝线是真实梯度，在 $t = 30$ 由 2 突变为 -2；黄点是加上贯穿例噪声后的单次读数；绿线是 $\beta = 0.9$ 的移动平均方向（按权重之和归一化）。绿线的抖动比黄点小得多，但突变后要约十轮才转向。

把两种效果算出来。先看平滑：设各轮读数的噪声相互独立，方差都是 σ^2。移动平均的噪声部分是加权和，独立项的方差按权重平方相加，

$$(1-\beta)^2 \sum_{s=0}^{t} \beta^{2s} \sigma^2 = \frac{1-\beta}{1+\beta}\left(1-\beta^{2(t+1)}\right)\sigma^2.$$

于是轮数足够多时，方差缩小的倍数是

$$\frac{1-\beta}{1+\beta}. \tag{13.53}$$

再看滞后：移动平均里读数的平均年龄是

$$\sum_{s=0}^{\infty} s(1-\beta)\beta^s = \frac{\beta}{1-\beta}. \tag{13.54}$$

取 $\beta = 0.9$，噪声方差缩小到约 0.053 倍，平均年龄却是 9 轮。图 13.21(b) 同时展示了两者：梯度不变时绿线紧贴真实值，梯度突变后绿线要约十轮

才转向。这两个计算都假定噪声与位置无关，只说明趋势：真实运行中读数的位置本身受过去的噪声影响。

动量不是当前梯度的无偏估计　读数条件无偏是说，固定历史后读数的均值等于当前梯度。动量方向并不继承这个性质。历史 $\mathcal{F}^{(t)}$ 确定了 $\boldsymbol{v}^{(t)}$，所以

$$\mathbb{E}\big[\boldsymbol{v}^{(t+1)} \mid \mathcal{F}^{(t)}\big] = \beta \boldsymbol{v}^{(t)} + \boldsymbol{g}^{(t)}, \tag{13.55}$$

只要 $\boldsymbol{v}^{(t)} \neq \mathbf{0}$ 且 $\beta > 0$，它就不等于当前梯度 $\boldsymbol{g}^{(t)}$。移动平均写法同样如此，条件均值是 $\beta \boldsymbol{m}^{(t)} + (1-\beta)\boldsymbol{g}^{(t)}$。前面基于条件无偏的单步下降递推，不能把 $\boldsymbol{v}^{(t+1)}$ 当成读数直接代入。

贯穿例给出具体的数。取 $\alpha = 0.1$，$\beta = 0.5$，第一轮抽到第 3 项后位于 $x^{(1)} = 2.3$，速度是 $v^{(1)} = -3$。此时三项梯度分别是 $5.3, 4.6, -2.1$，平均为 $f'(2.3) = 2.6$。第二轮的速度取 3.8、3.1、-3.6 三个值，条件均值是

$$\mathbb{E}\big[v^{(2)} \mid \mathcal{F}^{(1)}\big] = 0.5 \cdot (-3) + 2.6 = 1.1 \neq 2.6.$$

固定噪声下的稳态方差　动量究竟能不能降低噪声的影响？在可以精确计算的情形中回答。考虑一元二次目标、加性噪声，下面的定理给出重球法长期的方差。

定理 13.12　加性噪声下重球法的稳态方差　设 $f(x) = \frac{\lambda}{2}x^2$，$\lambda > 0$，读数为 $\hat{g}^{(t)} = \lambda x^{(t)} + \xi^{(t)}$，其中 $\xi^{(t)}$ 独立同分布，均值为零，方差为 σ^2，且与此前的迭代独立。设 $0 \le \beta < 1$，$0 < \alpha\lambda < 2(1+\beta)$。则式 (13.48)的迭代满足 $\mathbb{E}x^{(t)} \to 0$，并且

$$\lim_{t\to\infty} \mathbb{E}\big[(x^{(t)})^2\big] = \frac{\alpha\sigma^2(1+\beta)}{\lambda(1-\beta)\big(2(1+\beta) - \alpha\lambda\big)}. \tag{13.56}$$

证明　把式 (13.48)写成二阶递推。令 $a_1 = 1 + \beta - \alpha\lambda$，$a_2 = -\beta$，$s^2 = \alpha^2\sigma^2$，则

$$x^{(t+1)} = a_1 x^{(t)} + a_2 x^{(t-1)} - \alpha\xi^{(t)}.$$

特征方程是 $r^2 - a_1 r - a_2 = 0$。条件 $0 \le \beta < 1$ 与 $|a_1| < 1 + \beta$ 合起来保证两根都在单位圆内，这正是定理对 α 和 β 的要求。所以均值

的线性递推趋于零；二阶矩的线性递推的特征值是两根的两两乘积，也都在单位圆内，因而二阶矩收敛。记极限为

$$V_0 = \lim_{t\to\infty} \mathbb{E}\big[(x^{(t)})^2\big], \qquad V_1 = \lim_{t\to\infty} \mathbb{E}\big[x^{(t)}x^{(t-1)}\big].$$

递推两边乘以 $x^{(t)}$ 取期望。$\xi^{(t)}$ 与 $x^{(t)}$ 独立且均值为零，噪声项消失；取极限得到 $V_1 = a_1 V_0 + a_2 V_1$，也就是

$$V_1 = \frac{a_1 V_0}{1 - a_2}.$$

递推两边平方取期望，同样消去交叉项，取极限得到

$$V_0 = (a_1^2 + a_2^2)V_0 + 2a_1 a_2 V_1 + s^2.$$

把 V_1 代入，两边乘以 $1 - a_2$ 并整理，V_0 的系数变成

$$(1 - a_2)(1 - a_2^2) - a_1^2(1 - a_2) - 2a_1^2 a_2 = (1 + a_2)\big[(1 - a_2)^2 - a_1^2\big].$$

于是

$$V_0 = \frac{s^2(1 - a_2)}{(1 + a_2)\big[(1 - a_2)^2 - a_1^2\big]}.$$

代回 $1 - a_2 = 1 + \beta$，$1 + a_2 = 1 - \beta$，以及

$$(1 + \beta)^2 - (1 + \beta - \alpha\lambda)^2 = \alpha\lambda\big(2(1 + \beta) - \alpha\lambda\big),$$

约去一个 $\alpha\lambda$，即得式 (13.56)。 ■

看式 (13.56)怎样读。取 $\beta = 0$, 它变成常步长随机梯度下降的 $\alpha\sigma^2/(\lambda(2-\alpha\lambda))$。当 $\alpha\lambda$ 远小于 $1 + \beta$ 时，$2(1 + \beta) - \alpha\lambda \approx 2(1 + \beta)$，稳态方差约为

$$\frac{\alpha\sigma^2}{2\lambda(1 - \beta)} = \frac{\sigma^2}{2\lambda} \cdot \frac{\alpha}{1 - \beta}, \tag{13.57}$$

只取决于有效步长 $\alpha/(1-\beta)$。也就是说，步长很小时，动量的平滑效果恰好被有效步长的放大抵消：动量不改变噪声的稳态水平，它带来的是更快的初始收敛。

图 13.22(b) 验证了这一点：三个 β 的稳态目标差关于有效步长几乎是同一条线。图 13.22(a) 回到贯穿例，读数噪声随位置变化，定理的公式不再精确成立，但同样可以写出二阶矩的精确递推。$\alpha = 0.1$，$\beta = 0.5$ 的重球法稳态目标差约为 1.037，有效步长相同的 $\alpha = 0.2$ 的随机梯度下降约为 1.217，$\alpha = 0.1$ 的随机梯度下降约为 0.528。

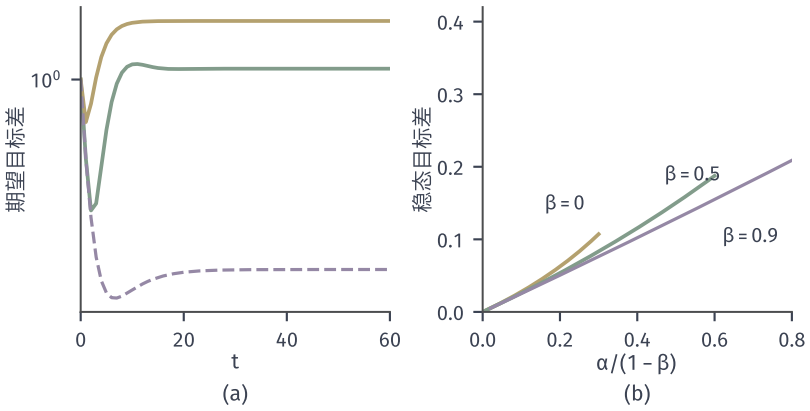


图 13.22 动量下的噪声残余。(a) 贯穿例、$x^{(0)}=2$ 的期望目标差，由二阶矩的精确递推得到。绿线是 $\alpha=0.1$，$\beta=0.5$ 的重球法；黄线是 $\alpha=0.2$ 的随机梯度下降，有效步长与绿线相同；紫色虚线是 $\alpha=0.1$ 的随机梯度下降。(b) 式 (13.56)给出的稳态目标差 $\frac{\lambda}{2}V_0$，$\lambda=2$，$\sigma^2=1$，横轴是有效步长。黄线、绿线、紫线分别取 $\beta=0,0.5,0.9$，三条线的 α 都取到 0.3 为止。

变量

- $\boldsymbol{x}^{(t)}\in\mathbb{R}^n$：当前参数。
- $\boldsymbol{v}^{(t)}\in\mathbb{R}^n$：速度，形状与参数相同，是算法状态的一部分。
- $\hat{\boldsymbol{g}}^{(t)}\in\mathbb{R}^n$：当前点的随机读数。
- $\alpha>0$，$0\le\beta<1$：固定的步长与动量系数。
- T：预定的总轮数。

初始化 令 $\boldsymbol{v}^{(0)}=\mathbf{0}$，第一轮没有历史，与一步随机梯度下降相同。例中是贯穿例的三项一元目标，取 $\alpha=0.1$，$\beta=0.5$，读取顺序为第 $3,1,2$ 项，起点和速度是

$$x^{(0)}=2,\qquad v^{(0)}=0.$$

每轮更新 在第 t 轮依次执行：

1. **抽样并读取**。抽取下标 $i^{(t)}$，在当前点读取 $\hat{\boldsymbol{g}}^{(t)}$。这一步使用的是更新前的位置。例中第一轮抽到第 3 项，

$$\hat{g}^{(0)}=f_3'(2)=-3.$$

2. **更新速度**。按式 (13.49)用旧速度和本轮读数计算 $\boldsymbol{v}^{(t+1)}$。例中第一轮

$$v^{(1)}=0.5\cdot 0+(-3)=-3.$$

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.4.1 随机重球法
13.4.2 随机 Nesterov 方法
13.4.3 Lion 符号动量（补充）
13.4.4 Muon 矩阵动量（补充）
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

3. **更新参数**。用新速度计算 $\boldsymbol{x}^{(t+1)}$，然后 $t \leftarrow t+1$。例中第一轮

$$x^{(1)} = 2 - 0.1 \cdot (-3) = 2.3.$$

第二轮抽到第 1 项，读数和速度是

$$\hat{g}^{(1)} = f_1'(2.3) = 5.3, \qquad v^{(2)} = 0.5 \cdot (-3) + 5.3 = 3.8,$$

于是

$$x^{(2)} = 2.3 - 0.38 = 1.92.$$

第三轮抽到第 2 项，读数和速度是

$$\hat{g}^{(2)} = f_2'(1.92) = 3.84, \qquad v^{(3)} = 0.5 \cdot 3.8 + 3.84 = 5.74,$$

于是

$$x^{(3)} = 1.92 - 0.574 = 1.346.$$

单次读数的大小不能作为停止依据，这里按预定轮数结束。例中 $T = 3$，最终得到 $x^{(3)} = 1.346$，目标差为 $(0.346)^2 \approx 0.120$。

保证与状态　随机重球法每轮只多一个 n 维向量和一次向量加法，读取次数不变。恢复运行时必须同时恢复 $\boldsymbol{v}^{(t)}$：只恢复参数，第一轮就退回了一步无动量的随机梯度下降。

一般目标上的保证要同时限定 α、β 和读数的条件。定理 13.12只针对二次目标和加性噪声。第 6章已经看到，重球法在一般强凸光滑目标上，用二次目标的最优参数可能循环；随机读数不会修复这一点。分析时要把 $(\boldsymbol{x}^{(t)}, \boldsymbol{v}^{(t)})$ 作为一个整体，常用的做法是构造同时包含目标差和速度的势函数，递推中的噪声项按所选的势函数进入。

13.4.2 随机 Nesterov 方法

主要思想　第 6章的 Nesterov 方法先沿动量探出去，到探出的位置再求梯度。随机版本的读数也放到这个前瞻点：

$$\begin{aligned} \boldsymbol{y}^{(t)} &= \boldsymbol{x}^{(t)} + \beta\big(\boldsymbol{x}^{(t)} - \boldsymbol{x}^{(t-1)}\big), \\ \boldsymbol{x}^{(t+1)} &= \boldsymbol{y}^{(t)} - \alpha \hat{\boldsymbol{g}}^{(t)}, \end{aligned} \tag{13.58}$$

这里 $\hat{\boldsymbol{g}}^{(t)}$ 是在 $\boldsymbol{y}^{(t)}$ 处读取的。图 13.23把两种方法的状态次序并排画出。

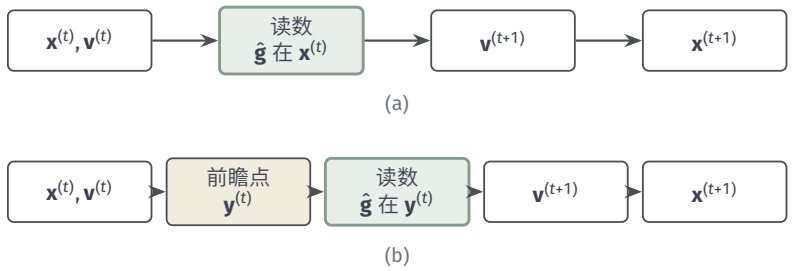


图 13.23 一轮内的状态次序。(a) 随机重球法在当前点读数，接着更新速度和参数。(b) 随机 Nesterov 方法先用历史算出前瞻点（黄），在前瞻点读数（绿），再更新速度和参数。两种方法的状态都是 $(\boldsymbol{x}^{(t)}, \boldsymbol{v}^{(t)})$，读取发生的位置不同。

$\boldsymbol{y}^{(t)}$ 由抽样之前的量算出，所以固定历史后它是确定的。读数的条件无偏因而写成

$$\mathbb{E}\big[\hat{\boldsymbol{g}}^{(t)} \mid \mathcal{F}^{(t)}\big] = \nabla f\big(\boldsymbol{y}^{(t)}\big). \tag{13.59}$$

这里被无偏估计的是前瞻点的梯度，不是 $\boldsymbol{x}^{(t)}$ 处的梯度，两者一般不同。下面的比较把这一差别和其他差别列在一起。

表 13.3 随机重球法与随机 Nesterov 方法的比较。

对比项	随机重球法	随机 Nesterov 方法
读数位置	当前点 $\boldsymbol{x}^{(t)}$	前瞻点 $\boldsymbol{y}^{(t)}$
条件无偏对象	$\nabla f(\boldsymbol{x}^{(t)})$	$\nabla f(\boldsymbol{y}^{(t)})$
状态	$\boldsymbol{x}^{(t)}, \boldsymbol{v}^{(t)}$	$\boldsymbol{x}^{(t)}, \boldsymbol{v}^{(t)}$
一般强凸光滑	最优参数可能循环	确定性时加速

贯穿例中取同样的 $\alpha = 0.1$，$\beta = 0.5$，读取顺序仍为第 $3, 1, 2$ 项。三轮的前瞻点、读数和新位置分别是

$$\begin{aligned} &y^{(0)} = 2, && \hat{g}^{(0)} = -3, && x^{(1)} = 2.3, \\ &y^{(1)} = 2.45, && \hat{g}^{(1)} = 5.45, && x^{(2)} = 1.905, \\ &y^{(2)} = 1.7075, && \hat{g}^{(2)} = 3.415, && x^{(3)} = 1.366. \end{aligned}$$

第二轮的读数 5.45 是 f_1' 在 $y^{(1)} = 2.45$ 处的值，而不是在 $x^{(1)} = 2.3$ 处的值。第三轮的前瞻点 1.7075 已经比 $x^{(2)} = 1.905$ 更靠近 $x^\star = 1$，读数相应变小。

方差怎样进入势函数 确定性的 Nesterov 方法靠势函数证明加速。把梯度换成带噪声的读数，势函数的递推发生什么变化？下面的定理说明，收缩因子保留，但多了一个不随步数消失的噪声项。记号沿用第 6章：$q = 1/\sqrt{\kappa}$，以 $\boldsymbol{u}^{(t)}$ 表示那里的辅助点。

定理 13.13　强凸情形下随机 Nesterov 方法的势函数递推　设 f 的梯度 L-Lipschitz 连续且 μ 强凸，$\mu > 0$，最优解为 $\boldsymbol{x}^\star$。取 $\alpha = 1/L$，$\beta = (1-q)/(1+q)$，$\boldsymbol{x}^{(-1)} = \boldsymbol{x}^{(0)}$。设前瞻点的读数满足

$$\begin{aligned} \hat{\boldsymbol{g}}^{(t)} &= \nabla f(\boldsymbol{y}^{(t)}) + \boldsymbol{\xi}^{(t)}, \\ \mathbb{E}\big[\boldsymbol{\xi}^{(t)} \mid \mathcal{F}^{(t)}\big] = \boldsymbol{0}, &\qquad \mathbb{E}\big[\|\boldsymbol{\xi}^{(t)}\|_2^2 \mid \mathcal{F}^{(t)}\big] \le \sigma^2. \end{aligned} \tag{13.60}$$

令 $\boldsymbol{u}^{(0)} = \boldsymbol{x}^{(0)}$，并记

$$\begin{aligned} \boldsymbol{u}^{(t+1)} &= \boldsymbol{x}^{(t)} + \frac{1}{q}\big(\boldsymbol{x}^{(t+1)} - \boldsymbol{x}^{(t)}\big), \\ \Phi^{(t)} &= f(\boldsymbol{x}^{(t)}) - f^\star + \frac{\mu}{2}\|\boldsymbol{u}^{(t)} - \boldsymbol{x}^\star\|_2^2. \end{aligned} \tag{13.61}$$

则

$$\mathbb{E}\big[\Phi^{(t+1)} \mid \mathcal{F}^{(t)}\big] \le (1-q)\Phi^{(t)} + \frac{\sigma^2}{L}, \tag{13.62}$$

因而

$$\mathbb{E} f(\boldsymbol{x}^{(T)}) - f^\star \le (1-q)^T \Phi^{(0)} + \frac{\sqrt{\kappa}\,\sigma^2}{L}. \tag{13.63}$$

证明　固定一步，省略上标 (t)，记 $\boldsymbol{g} = \nabla f(\boldsymbol{y})$，下一步的点记为 $\boldsymbol{x}^+$ 和 $\boldsymbol{u}^+$。

第一步，建立两个恒等式：

$$\boldsymbol{y} = \frac{\boldsymbol{x} + q\boldsymbol{u}}{1+q}, \qquad \boldsymbol{u}^+ = (1-q)\boldsymbol{u} + q\boldsymbol{y} - \frac{q}{\mu}\hat{\boldsymbol{g}}.$$

这两个等式只用到更新形式 $\boldsymbol{x}^+ = \boldsymbol{y} - \hat{\boldsymbol{g}}/L$，读数是否带噪声不影响代数。第一式在 $t = 0$ 时成立，因为 $\boldsymbol{y}^{(0)} = \boldsymbol{u}^{(0)} = \boldsymbol{x}^{(0)}$。设第一式对 t 成立，则 $q\boldsymbol{u} = (1+q)\boldsymbol{y} - \boldsymbol{x}$，代入第二式右端，并用 $q/\mu = 1/(qL)$，得到

$$\frac{1}{q}\big(\boldsymbol{y} - \tfrac{1}{L}\hat{\boldsymbol{g}} - (1-q)\boldsymbol{x}\big) = \boldsymbol{x} + \frac{1}{q}(\boldsymbol{x}^+ - \boldsymbol{x}) = \boldsymbol{u}^+.$$

再由 $\boldsymbol{u}^+$ 的定义和 $\beta = (1-q)/(1+q)$，计算

$$\frac{\boldsymbol{x}^+ + q\boldsymbol{u}^+}{1+q} = \boldsymbol{x}^+ + \frac{1-q}{1+q}(\boldsymbol{x}^+ - \boldsymbol{x}) = \boldsymbol{y}^{(t+1)},$$

所以第一式对 $t+1$ 也成立。

第二步，函数项。由下降引理，

$$f(\boldsymbol{x}^+) \le f(\boldsymbol{y}) - \frac{1}{L}\langle \boldsymbol{g}, \hat{\boldsymbol{g}}\rangle + \frac{1}{2L}\|\hat{\boldsymbol{g}}\|_2^2.$$

固定 $\mathcal{F}^{(t)}$ 取条件期望。噪声的条件均值为零，交叉项消失，于是

$$\mathbb{E}\hat{\boldsymbol{g}} = \boldsymbol{g}, \qquad \mathbb{E}\|\hat{\boldsymbol{g}}\|_2^2 \le \|\boldsymbol{g}\|_2^2 + \sigma^2.$$

代入上式，得到

$$\mathbb{E} f(\boldsymbol{x}^{+}) \le f(\boldsymbol{y}) - \frac{1}{2L}\|\boldsymbol{g}\|_2^2 + \frac{\sigma^2}{2L}.$$

第三步，距离项。记 $\boldsymbol{w} = (1-q)\boldsymbol{u} + q\boldsymbol{y}$，它由历史确定，$\boldsymbol{u}^{+} = \boldsymbol{w} - \frac{q}{\mu}\hat{\boldsymbol{g}}$。展开平方，用 $q^2/(2\mu) = 1/(2L)$，取条件期望，得到

$$\frac{\mu}{2}\mathbb{E}\|\boldsymbol{u}^{+} - \boldsymbol{x}^{\star}\|_2^2 \le \frac{\mu}{2}\|\boldsymbol{w} - \boldsymbol{x}^{\star}\|_2^2 - q\langle \boldsymbol{g}, \boldsymbol{w} - \boldsymbol{x}^{\star}\rangle + \frac{1}{2L}\big(\|\boldsymbol{g}\|_2^2 + \sigma^2\big).$$

第四步，相加。两式相加，$\|\boldsymbol{g}\|_2^2$ 相消，噪声项合计 σ^2/L。剩下的部分完全由历史确定：

$$\mathbb{E}\Phi^{(t+1)} \le f(\boldsymbol{y}) - f^{\star} + \frac{\mu}{2}\|\boldsymbol{w} - \boldsymbol{x}^{\star}\|_2^2 - q\langle \boldsymbol{g}, \boldsymbol{w} - \boldsymbol{x}^{\star}\rangle + \frac{\sigma^2}{L}.$$

第五步，处理确定部分，与精确梯度时相同。平方范数的凸性给出

$$\|\boldsymbol{w} - \boldsymbol{x}^{\star}\|_2^2 \le (1-q)\|\boldsymbol{u} - \boldsymbol{x}^{\star}\|_2^2 + q\|\boldsymbol{y} - \boldsymbol{x}^{\star}\|_2^2.$$

把 $\boldsymbol{w} - \boldsymbol{x}^{\star}$ 写成 $(1-q)(\boldsymbol{u} - \boldsymbol{y}) + (\boldsymbol{y} - \boldsymbol{x}^{\star})$，并由强凸性得到

$$\langle \boldsymbol{g}, \boldsymbol{y} - \boldsymbol{x}^{\star}\rangle \ge f(\boldsymbol{y}) - f^{\star} + \frac{\mu}{2}\|\boldsymbol{y} - \boldsymbol{x}^{\star}\|_2^2.$$

两式代入后，$\|\boldsymbol{y} - \boldsymbol{x}^{\star}\|_2^2$ 项抵消，右端成为

$$(1-q)\big(f(\boldsymbol{y}) - f^{\star}\big) + (1-q)\frac{\mu}{2}\|\boldsymbol{u} - \boldsymbol{x}^{\star}\|_2^2 - q(1-q)\langle \boldsymbol{g}, \boldsymbol{u} - \boldsymbol{y}\rangle + \frac{\sigma^2}{L}.$$

第六步，由第一个恒等式，$q(\boldsymbol{u} - \boldsymbol{y}) = \boldsymbol{y} - \boldsymbol{x}$，所以内积项等于 $(1-q)\langle \boldsymbol{g}, \boldsymbol{x} - \boldsymbol{y}\rangle$。凸性给出

$$\langle \boldsymbol{g}, \boldsymbol{x} - \boldsymbol{y}\rangle \le f(\boldsymbol{x}) - f(\boldsymbol{y}),$$

于是 $f(\boldsymbol{y})$ 消去，得到式 (13.62)。

最后对 t 取全期望并迭代，用 $\sum_{j<T}(1-q)^j \le 1/q = \sqrt{\kappa}$，得到式 (13.63)。 ■

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.4.1 随机重球法
13.4.2 随机 Nesterov 方法
13.4.3 Lion 符号动量（补充）
13.4.4 Muon 矩阵动量（补充）
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

定理的两个条件起不同的作用。条件无偏保证了函数项和距离项中的一次项按精确梯度计算，这是用到式 (13.60)第一式的地方。方差界让二次项多出 $\sigma^2/(2L)$，函数项和距离项各一份。

与确定性结果的差别在于式 (13.63)最后一项。确定性时目标差按 $(1-q)^T$ 收缩到零；有噪声时只能收缩到量级 $\sqrt{\kappa}\sigma^2/L$ 的邻域，这一项不随 T 消失。所以确定性的加速界不能靠把梯度换成读数直接继承，要进一步下降就要改用更小的步长或增大批量，收缩因子也要随之调整。

式 (13.63)是上界，不同方法的上界不宜直接比较。在二次目标上可以写出精确的稳态值。图 13.24用第 6章的目标 $f=(x_1^2+9x_2^2)/2$ 和起点 $(9,1)$ 比较三种方法。无噪声时，重球法和 Nesterov 方法远快于梯度下降。加入方差为 1 的加性噪声后，梯度下降、重球法、Nesterov 方法的稳态目标差分别约为 0.085、0.926、0.108。重球法这组参数的有效步长是 $1/3$，大于梯度下降的 $1/9$；更重要的是 $\lambda=9$ 时 $\alpha\lambda=2.25$，已接近稳定边界 $2(1+\beta)=2.5$，式 (13.56)的分母很小，噪声残余被放大约 11 倍。Nesterov 方法的残余低于定理的上界 $\sqrt{\kappa}\sigma^2/L=1/3$。

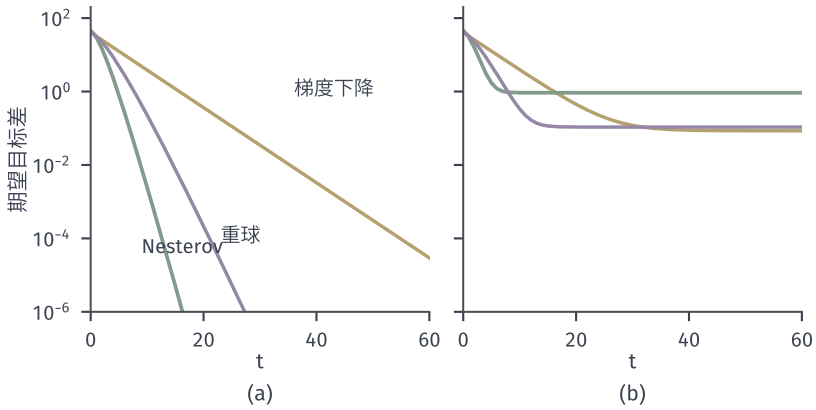


图 13.24　目标 $f=(x_1^2+9x_2^2)/2$，起点 $(9,1)$，由二阶矩的精确递推得到的期望目标差。(a) 无噪声。(b) 读数加上各分量方差为 1 的独立噪声。黄线是 $\alpha=1/9$ 的梯度下降，绿线是 $\alpha=\beta=1/4$ 的重球法，紫线是 $\alpha=1/9$，$\beta=1/2$ 的 Nesterov 方法。加速缩短了初始阶段，重球法的稳态残余明显更高。

13.4.3 Lion 符号动量（补充）

算法　前两种方法的方向都保留读数的幅度。Lion 只取方向的符号：把动量和本轮读数组成候选方向，逐坐标取符号，再按固定步长移动[5]。记 $\operatorname{sign}(\cdot)$ 逐坐标作用。取 $\boldsymbol{m}^{(0)}=\mathbf{0}$，系数 $\beta_1,\beta_2\in[0,1)$，收缩系数 $\gamma\ge 0$，每轮读取 $\hat{\boldsymbol{g}}^{(t)}$ 后依次计算候选方向和参数更新：

$$\begin{aligned}\boldsymbol{c}^{(t)}&=\beta_1\boldsymbol{m}^{(t)}+(1-\beta_1)\hat{\boldsymbol{g}}^{(t)},\\ \boldsymbol{x}^{(t+1)}&=\boldsymbol{x}^{(t)}-\alpha\operatorname{sign}\bigl(\boldsymbol{c}^{(t)}\bigr)-\alpha\gamma\boldsymbol{x}^{(t)}.\end{aligned}\tag{13.64}$$

[5] X. Chen, C. Liang, D. Huang, E. Real, K. Wang, Y. Liu, H. Pham, X. Dong, T. Luong, C.-J. Hsieh, Y. Lu, Q. V. Le, *Symbolic Discovery of Optimization Algorithms* In Advances in Neural Information Processing Systems 36, 2023

候选方向只参与这一步，下一轮用的动量由另一个系数单独记录：

$$\boldsymbol{m}^{(t+1)} = \beta_2 \boldsymbol{m}^{(t)} + (1-\beta_2)\hat{\boldsymbol{g}}^{(t)}. \tag{13.65}$$

β_1 决定当前方向里旧动量占多少，β_2 决定动量本身记忆多长，常见取值是 $\beta_1 = 0.9$，$\beta_2 = 0.99$。因此读数在方向里的权重是 $1-\beta_1$，在历史中的权重却是 $1-\beta_2$，两者分开调节。

舍弃幅度 符号操作舍弃了幅度。设候选方向是 $\boldsymbol{c} = (0.1, 3)$，同向但两个坐标相差 30 倍，取符号后是 $(1,1)$，两个坐标移动相同的距离。图 13.25(a) 对比了这一点。优点是位移的大小完全由步长决定，读数的尺度和离群值都不会放大位移；缺点是信息少了，当前读数是否接近零，算法并不知道。

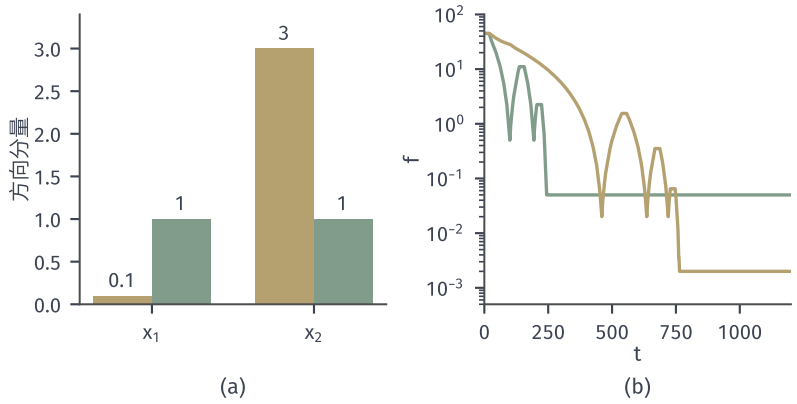


图 13.25 符号方向的效果。(a) 候选方向 $(0.1, 3)$（黄）与其符号 $(1,1)$（绿）。(b) 目标 $f = (x_1^2 + 9x_2^2)/2$ 上 $\gamma = 0$ 的 Lion，使用精确梯度，纵轴是最近 20 轮内 f 的最大值。绿线 $\alpha = 0.1$，黄线 $\alpha = 0.02$。下降段之后曲线不再改善，平台高度随步长变化。

贯穿例的三轮 取 $\alpha = 0.1$，$\beta_1 = 0.9$，$\beta_2 = 0.99$，$\gamma = 0$，$x^{(0)} = 2$，$m^{(0)} = 0$，读取顺序仍为第 3, 1, 2 项。三轮的读数、候选方向、新位置和新动量依次是

$$\begin{aligned}
&\hat{g}^{(0)} = -3, \quad c^{(0)} = -0.3, \quad x^{(1)} = 2.1, \quad m^{(1)} = -0.03,\\
&\hat{g}^{(1)} = 5.1, \quad c^{(1)} = 0.483, \quad x^{(2)} = 2.0, \quad m^{(2)} = 0.0213,\\
&\hat{g}^{(2)} = 4, \quad\ c^{(2)} = 0.419, \quad x^{(3)} = 1.9, \quad m^{(3)} = 0.0611.
\end{aligned}$$

第一轮的候选方向由反向读数决定，参数上升；此后两轮都下降。读数的大小从 3 变到 5.1，每轮的位移却都是 0.1。

分别核对三个量 第一个量是实际位移：$\gamma = 0$ 时每个坐标的位移大小恰好是 α（候选方向该坐标非零时），不随读数减小。第二个量是原目标的残差。以 $\beta_1 = 0$ 的一元精确梯度为例，每步的位移都是 α，迭代最后在

距 $x^\star$ 不超过 α 的范围内来回，残差不会趋于零；$\beta_1 > 0$ 时候选方向有滞后，来回的范围由动量决定，同样不会随步数消失。图 13.25(b) 取 $\beta_1 = 0.9$，$\beta_2 = 0.99$，平台的最高值在 $\alpha = 0.1$ 时是 0.05，在 $\alpha = 0.02$ 时是 0.002，减小残差要靠减小步长。

第三个量是参数收缩。γ 项按更新前的参数做收缩，独立于读数和符号。它把参数往原点拉，不是原目标的下降方向，所以残差要按原目标 f 计算，不能把含收缩的位移当成 f 的下降。

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.4.1 随机重球法
13.4.2 随机 Nesterov 方法
13.4.3 Lion 符号动量（补充）
13.4.4 Muon 矩阵动量（补充）
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

13.4.4 Muon 矩阵动量（补充）

问题：把矩阵动量变换成更新方向 参数是矩阵 $\boldsymbol{W} \in \mathbb{R}^{m\times d}$ 时，动量 $\boldsymbol{B}$ 也是矩阵。Lion 逐元素地把幅度抹去，Muon 在奇异方向上做类似的事：保留动量的奇异向量，把奇异值全部变成 1[6]。

这正是极分解所做的。矩形矩阵 $\boldsymbol{B}$ 的紧奇异值分解是 $\boldsymbol{B} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$，极分解把它写成部分等距与半正定因子之积，

$$\boldsymbol{B} = \boldsymbol{U}\boldsymbol{V}^\top \cdot \boldsymbol{V}\boldsymbol{\Sigma}\boldsymbol{V}^\top, \qquad \operatorname{orth}(\boldsymbol{B}) = \boldsymbol{U}\boldsymbol{V}^\top. \tag{13.66}$$

这里 $\boldsymbol{U}\boldsymbol{V}^\top$ 就是**极因子**（polar factor），奇异向量与 $\boldsymbol{B}$ 相同，奇异值全部是 1。极分解的存在性和唯一性条件可参考卷二第 8 章“极分解”。

奇异值分解太贵，Muon 用矩阵多项式的有限次迭代来近似极因子。设 $\boldsymbol{X} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$，对奇次多项式 $p(\sigma) = \sum_j c_j \sigma^{2j+1}$，有

$$\sum_j c_j \boldsymbol{X}\left(\boldsymbol{X}^\top\boldsymbol{X}\right)^j = \boldsymbol{U}\, p(\boldsymbol{\Sigma})\, \boldsymbol{V}^\top, \tag{13.67}$$

所以这样的迭代不改变奇异向量，只对每个奇异值作用多项式。于是问题变成：选 p，使得多次复合后所有奇异值都接近 1。

算法次序 一次更新的次序是：

1. **读取**。在当前点（或前瞻点）得到矩阵读数 $\hat{\boldsymbol{G}}^{(t)}$。
2. **更新动量**。用旧动量和本轮读数计算

$$\boldsymbol{B}^{(t+1)} = \beta \boldsymbol{B}^{(t)} + \hat{\boldsymbol{G}}^{(t)}. \tag{13.68}$$

3. **归一化**。用 Frobenius 范数除以动量，得到

$$\boldsymbol{X}_0 = \frac{\boldsymbol{B}^{(t+1)}}{\|\boldsymbol{B}^{(t+1)}\|_{\mathrm{F}}},$$

所有非零奇异值落到 $(0, 1]$。

[6] K. Jordan, Y. Jin, V. Boza, J. You, F. Cesista, L. Newhouse, J. Bernstein, *Muon: An Optimizer for Hidden Layers in Neural Networks*, Dec. 8, 2024, URL: https://kellerjordan.github.io/posts/muon/ (visited on 10/04/2026)

4. **有限次迭代**。按多项式迭代 k 次，得到 $\boldsymbol{X}_k$。
5. **更新参数**。$\boldsymbol{W}^{(t+1)} = \boldsymbol{W}^{(t)} - \alpha \boldsymbol{X}_k$。

经典的 Newton–Schulz 迭代取 $p(\sigma) = \frac{1}{2}(3\sigma - \sigma^3)$，矩阵形式是

$$\boldsymbol{X}_{j+1} = \frac{3}{2}\boldsymbol{X}_j - \frac{1}{2}\boldsymbol{X}_j\boldsymbol{X}_j^{\top}\boldsymbol{X}_j. \tag{13.69}$$

这个 p 有不动点 $\sigma = 1$，导数 $p'(1) = 0$，所以在 1 附近二阶收敛；对 $\sigma \in (0, 1]$ 迭代单调上升到 1，起点离零很近时每步只放大约 1.5 倍。归一化保证了奇异值落在收敛区域里。

理想极因子与有限步近似 用具体矩阵计算。取

$$\boldsymbol{B} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

它的奇异值是 $4, 2$，奇异向量相同，极因子是单位矩阵 $\boldsymbol{I}$。按 Frobenius 范数 $\sqrt{20}$ 归一化后，奇异值是

$$0.894, \qquad 0.447.$$

由式 (13.69)迭代一次，两个奇异值变成 0.984 和 0.626；迭代三次是 1.000 和 0.953；迭代五次是 1.000 和 0.99998，已经非常接近理想的极因子 $\boldsymbol{I}$。图 13.26(a) 画出一般的 σ：奇异值越小，需要的迭代次数越多。

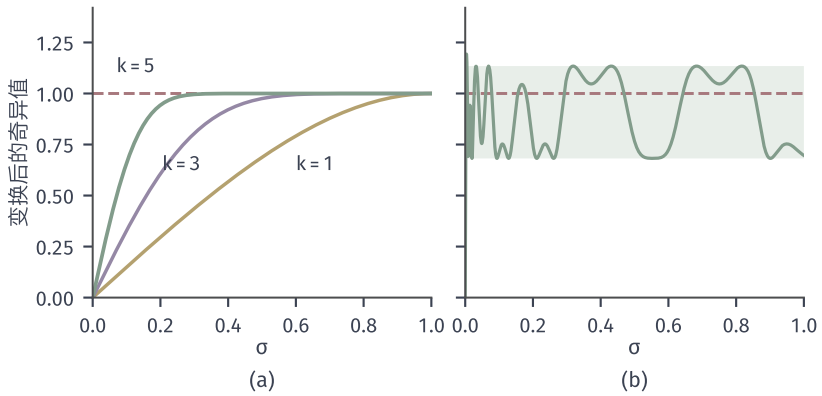


图 13.26 有限次迭代对奇异值的作用，横轴是归一化后的奇异值，红色虚线是理想的 1。(a) 经典 Newton–Schulz 迭代 $k = 1, 3, 5$ 次。(b) 五次多项式 $3.4445\sigma - 4.7750\sigma^3 + 2.0315\sigma^5$ 复合 5 次，绿底是 $\sigma \in [0.02, 1]$ 上的取值范围，约为 $[0.68, 1.13]$。

实际实现常用五次多项式[7]。:

[7] K. Jordan, Y. Jin, V. Boza, J. You, F. Cesista, L. Newhouse, J. Bernstein, *Muon: An Optimizer for Hidden Layers in Neural Networks*, Dec. 8, 2024, URL: https://kellerjordan.github.io/posts/muon/ (visited on 10/04/2026)

$$p(\sigma) = 3.4445\,\sigma - 4.7750\,\sigma^3 + 2.0315\,\sigma^5. \tag{13.70}$$

它的系数是为“只迭代五次”专门选的。$p(1) = 0.701$，$\sigma = 1$ 不是它的不动点，继续迭代不会收敛到极因子。它的优势是小奇异值被放大得更快：在图 13.26(b) 中，$\sigma \in [0.02, 1]$ 上五次复合后的值都落在约 $[0.68, 1.13]$ 内。

上面的矩阵用五次多项式迭代五次，奇异值变成 1.114 和 0.689，与理想值 1 差得较远；两个奇异值之比从 2 缩小到约 1.6。所以 $\boldsymbol{X}_k$ 是对动量的尺度压缩，而不是精确的极因子。

计算成本与含义　设 $m \geq d$，先把 $\boldsymbol{X}^{\top}\boldsymbol{X}$ 算出来。每次迭代做一次 $\boldsymbol{X}^{\top}\boldsymbol{X}$、一次 $(\boldsymbol{X}^{\top}\boldsymbol{X})^2$ 和一次 $\boldsymbol{X}$ 右乘，运算量是 $O(md^2)$；迭代 k 次合计 $O(kmd^2)$。完整的奇异值分解也是这个量级，但常数更大。比较方法时，这部分要计入，每步的读取次数不变不等于每步成本不变。

动量矩阵和它的变换都只由梯度读数算出，其中没有二阶导数。奇异值变成 1 是对历史读数的幅度处理，它不是目标 Hessian 的近似。这种方法在什么问题上有效，只能在具体问题上由实际的目标值或验证指标判断。

13.5 自适应更新

动量决定历史读数怎样合成方向。本节研究历史读数的另一种用途：根据过去读数的幅度，决定每个坐标或每个矩阵方向的更新尺度。不同坐标的读数幅度可能相差几个量级，同一个步长对它们不合适。这些方法都写成

$$\boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} - \alpha^{(t)}\boldsymbol{D}^{(t)}\hat{\boldsymbol{g}}^{(t)}, \tag{13.71}$$

或把 $\hat{\boldsymbol{g}}^{(t)}$ 换成动量方向，其中 $\boldsymbol{D}^{(t)}$ 是由历史读数算出的缩放。

$\boldsymbol{D}^{(t)}$ 的算法各不相同，但有一个共同的分析障碍：尺度和当前读数通常相关。如果 $\boldsymbol{D}^{(t)}$ 在本轮抽样之前已经确定，它可以从条件期望中提到外面；这里不行，$\boldsymbol{D}^{(t)}$ 往往用到了本轮读数。一元的第一步最能说明问题。设累计统计用本轮读数，则第一步的方向是

$$\frac{\hat{g}}{\sqrt{\hat{g}^2}} = \operatorname{sign}(\hat{g}).$$

在贯穿例的 $x^{(0)} = 2$ 处，三项读数是 $5, 4, -3$。缩放后的方向分别是 $1, 1, -1$，条件均值为

$$\frac{1}{3}\bigl(1 + 1 - 1\bigr) = \frac{1}{3},$$

而 $f'(2) = 2$。这个差别不是一个固定的比例因子：缩放后的条件均值由读数的分布决定，与 $f'(2)$ 的大小没有固定关系。

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.5.1 AdaGrad
13.5.2 RMSProp
13.5.3 Adam
13.5.4 AMSGrad
13.5.5 AdamW
13.5.6 Adafactor 统计压缩（补充）
13.5.7 Shampoo 矩阵预条件（补充）
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

所以下面每个方法都要写清统计量的更新次序，并分开说明保证所依赖的假设。全节沿用贯穿例的三轮读取，步长记作 α，稳定项 $\epsilon > 0$ 在手算中忽略。所有除法、平方根和乘方都逐坐标进行，$\odot$ 表示逐元素乘法。

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.5.1 AdaGrad
13.5.2 RMSProp
13.5.3 Adam
13.5.4 AMSGrad
13.5.5 AdamW
13.5.6 Adafactor 统计压缩（补充）
13.5.7 Shampoo 矩阵预条件（补充）
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

13.5.1 AdaGrad

累计平方与稀疏坐标 设想一个分类问题，特征是某些词是否出现。常见词在几乎每个样本中出现，对应坐标的读数频繁非零；罕见词偶尔才出现。用同一个步长，罕见词的坐标几乎没有机会被更新。AdaGrad 为每个坐标累计读数的平方，用它的平方根缩放当前读数[8]。取 $\boldsymbol{s}^{(0)} = \mathbf{0}$，读数之后先更新统计，再用新统计更新参数：

$$\boldsymbol{s}^{(t+1)} = \boldsymbol{s}^{(t)} + \hat{\boldsymbol{g}}^{(t)} \odot \hat{\boldsymbol{g}}^{(t)}, \qquad \boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} - \alpha \frac{\hat{\boldsymbol{g}}^{(t)}}{\sqrt{\boldsymbol{s}^{(t+1)}} + \epsilon}. \tag{13.72}$$

这里 $\boldsymbol{s}$ 是累计统计，ϵ 只防止分母为零。第 j 个坐标的有效系数是 $\alpha/(\sqrt{s_j^{(t+1)}} + \epsilon)$。读数频繁非零的坐标累计得快，系数缩小得快；稀疏坐标累计得慢，系数保持较大。

两个坐标的短序列 下面用一个短序列计算有效系数。取 $\alpha = 1$，忽略 ϵ。坐标 1 每轮读数都是 1，坐标 2 只在 $t = 0$ 和 $t = 3$ 读数为 1，其余轮读数为零，不发生位移。表 13.4列出每轮作用在非零读数上的系数。

表 13.4 有效系数 $\alpha/\sqrt{s_j^{(t+1)}}$ 的比较，$\alpha = 1$，忽略稳定项。坐标 2 只在 $t = 0, 3$ 读数为 1，其余轮读数为零，记作“—”。RMSProp 取 $\rho = 0.9$。

	AdaGrad		RMSProp	
轮次 t	坐标 1	坐标 2	坐标 1	坐标 2
0	1.000	1.000	3.162	3.162
1	0.707	—	2.294	—
2	0.577	—	1.921	—
3	0.500	0.707	1.705	2.405
4	0.447	—	1.563	—
5	0.408	—	1.461	—

AdaGrad 的两列中，坐标 1 的系数按 $1/\sqrt{t+1}$ 持续缩小，到 $t = 3$ 是 0.5；坐标 2 到 $t = 3$ 才累计了两次，系数是 0.707。稀疏的坐标因此保留了较大的步长。

累计统计的问题是不会忘记旧尺度。设某坐标前 10 轮的读数幅度是 10，之后幅度都是 1。前 10 轮累计了 1000，此后每轮只增加 1，到第 80 轮累

[8] J. Duchi, E. Hazan, Y. Singer, *Adaptive Subgradient Methods for Online Learning and Stochastic Optimization* In Journal of Machine Learning Research, 2011, vol. 12, no. 61, pp. 2121–2159

计量约为 1070，系数约为 0.031。图 13.27(b) 中的黄线显示了这一点：早期的大读数使有效系数永久偏小，算法可能在远离解时就几乎不再移动。

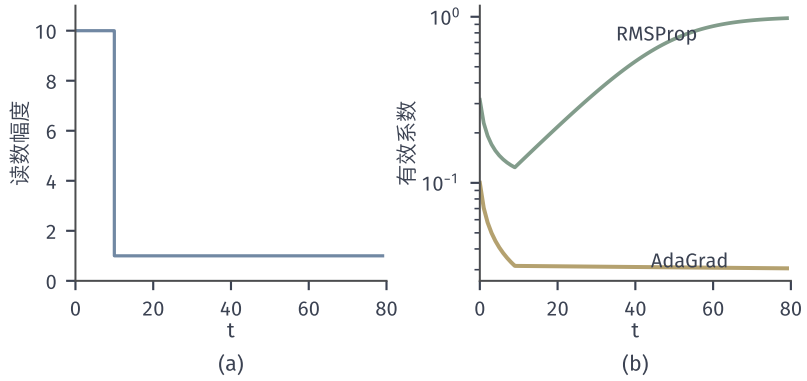


图 13.27 同一读数序列下的有效系数，$\alpha = 1$，忽略稳定项。(a) 读数幅度：前 10 轮为 10，之后为 1。(b) 有效系数的对数图。黄线是 AdaGrad，累计统计使系数一直偏小；绿线是 $\rho = 0.9$ 的 RMSProp，大读数被遗忘后系数恢复到接近 1。

保证的范围 AdaGrad 的额外状态是一个 n 维向量，每轮额外计算量 $O(n)$。保证按问题类型分别成立，引用时要注明。

- 凸在线问题：对手依次给出凸损失，算法在有界可行域上行动，读数有界。评价对象是遗憾，也就是累计损失减去最好的固定决策的累计损失。原始分析给出 $O(\sqrt{T})$ 的遗憾，并在读数稀疏时有更好的常数[9]。
- 随机凸问题：读数条件无偏时，可以由在线遗憾得到平均迭代的期望目标差，量级是 $O(1/\sqrt{T})$，同样需要有界可行域或相应的有界假设。
- 非凸光滑问题：评价对象是平方梯度范数的平均，需要读数有界或其他尾部条件，分母里的当前读数一般要特别处理。这类结果依赖具体的算法形式和假设，不能从凸的情形类推。

从更新形式本身推不出“比梯度下降快”。逐坐标缩放只有在问题的难点与坐标轴对齐时才有优势，图 13.29会展示这一边界。

13.5.2 RMSProp

用指数移动平均遗忘旧尺度 AdaGrad 难以遗忘，RMSProp 把累计和换成**指数移动平均**（exponential moving average）[10]。取衰减系数 $\rho \in [0, 1)$，$\boldsymbol{s}^{(0)} = \mathbf{0}$：

$$\boldsymbol{s}^{(t+1)} = \rho \boldsymbol{s}^{(t)} + (1-\rho)\hat{\boldsymbol{g}}^{(t)} \odot \hat{\boldsymbol{g}}^{(t)}, \qquad \boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} - \alpha \frac{\hat{\boldsymbol{g}}^{(t)}}{\sqrt{\boldsymbol{s}^{(t+1)}} + \epsilon}. \tag{13.73}$$

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.5.1 AdaGrad
13.5.2 RMSProp
13.5.3 Adam
13.5.4 AMSGrad
13.5.5 AdamW
13.5.6 Adafactor 统计压缩（补充）
13.5.7 Shampoo 矩阵预条件（补充）
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

[9] J. Duchi, E. Hazan, Y. Singer, *Adaptive Subgradient Methods for Online Learning and Stochastic Optimization* In Journal of Machine Learning Research, 2011, vol. 12, no. 61, pp. 2121–2159

[10] G. Hinton, *Neural Networks for Machine Learning: Lecture 6*, University of Toronto, 2012, URL: https://www.cs.toronto.edu/~tijmen/csc321/slides/lecture_slides_lec6.pdf (visited on 10/04/2026)

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.5.1 AdaGrad
13.5.2 RMSProp
13.5.3 Adam
13.5.4 AMSGrad
13.5.5 AdamW
13.5.6 Adafactor 统计压缩（补充）
13.5.7 Shampoo 矩阵预条件（补充）
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

顺序与 AdaGrad 相同：先读，再用本轮读数更新 $\boldsymbol{s}$，最后用新统计缩放本轮读数。ϵ 放在根号外，有的实现把它放在根号内，两者在分母很小时行为不同，记录实现时要写明。

展开递推，得到

$$\boldsymbol{s}^{(t+1)} = (1-\rho)\sum_{r=0}^{t} \rho^{t-r}\hat{\boldsymbol{g}}^{(r)} \odot \hat{\boldsymbol{g}}^{(r)}.$$

s 轮之前的读数平方的权重是 $(1-\rho)\rho^s$，大约只记住最近 $1/(1-\rho)$ 轮。$\rho = 0.9$ 时约为 10 轮。

零初始化的早期偏差 权重之和是 $1-\rho^{t+1}$，早期小于 1。读数恒为 g 时，

$$s^{(t+1)} = \left(1-\rho^{t+1}\right)g^2,$$

早期分母偏小，有效系数偏大。表 13.4的 RMSProp 列中，第一轮的系数是 $1/\sqrt{0.1} \approx 3.162$，比 AdaGrad 大得多。

再看图 13.27的序列：前 10 轮把分母抬到约 8，读数变小后，统计量大约以因子 ρ 逐轮衰减。第 30 轮的有效系数已经回到约 0.35，第 79 轮约为 0.98。

指数平均让尺度跟上最近的幅度，但它不提供一般的收敛保证。分母可能在大读数过后迅速变小，有效系数随之变大，下一节将看到这在特定问题上可能破坏收敛。

13.5.3 Adam

主要思想 RMSProp 的分子只用当前读数。Adam 在分子上也用移动平均，并修正两个平均的零初始化偏差[11]。取 $\beta_1, \beta_2 \in [0,1)$，一阶统计 $\boldsymbol{m}$ 与平方统计 $\boldsymbol{s}$ 从零开始，读取本轮读数后依次计算

$$\begin{aligned}\boldsymbol{m}^{(t+1)} &= \beta_1 \boldsymbol{m}^{(t)} + (1-\beta_1)\hat{\boldsymbol{g}}^{(t)},\\ \boldsymbol{s}^{(t+1)} &= \beta_2 \boldsymbol{s}^{(t)} + (1-\beta_2)\hat{\boldsymbol{g}}^{(t)} \odot \hat{\boldsymbol{g}}^{(t)}.\end{aligned} \tag{13.74}$$

零初始化带来的偏差如何修正？展开 $\boldsymbol{m}^{(t+1)}$，权重是 $(1-\beta_1)\beta_1^{t-r}$，加起来是 $1-\beta_1^{t+1}$，不是 1。把统计量除以权重之和，得到两个修正量：

$$\hat{\boldsymbol{m}}^{(t+1)} = \frac{\boldsymbol{m}^{(t+1)}}{1-\beta_1^{t+1}}, \qquad \hat{\boldsymbol{s}}^{(t+1)} = \frac{\boldsymbol{s}^{(t+1)}}{1-\beta_2^{t+1}}. \tag{13.75}$$

读数恒为常数 $\boldsymbol{g}$ 时，修正后 $\hat{\boldsymbol{m}}^{(t+1)} = \boldsymbol{g}$，$\hat{\boldsymbol{s}}^{(t+1)} = \boldsymbol{g} \odot \boldsymbol{g}$，每一轮都恰好是常数读数的值。

[11] D. P. Kingma, J. Ba, *Adam: A Method for Stochastic Optimization* In International Conference on Learning Representations, 2015

参数更新使用修正后的量：

$$\boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} - \alpha \frac{\hat{\boldsymbol{m}}^{(t+1)}}{\sqrt{\hat{\boldsymbol{s}}^{(t+1)}} + \epsilon}. \tag{13.76}$$

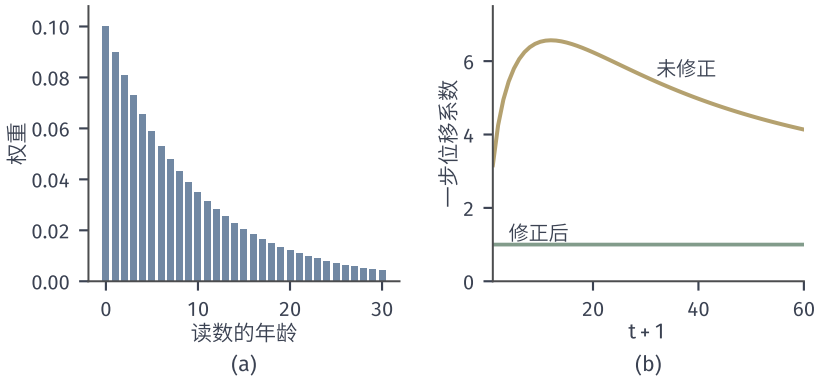


图 13.28　Adam 的零初始化修正，$\beta_1 = 0.9$，$\beta_2 = 0.999$，读数恒为 1，忽略稳定项。(a)$\boldsymbol{m}$ 的权重 $(1-\beta_1)\beta_1^s$，s 是读数的年龄。(b) 一步位移的系数：黄线是未修正的 $m/\sqrt{s}$，第一步约 3.16，之后更大；绿线是修正后的 $\hat{m}/\sqrt{\hat{s}}$，恒为 1。

图 13.28(b) 说明了修正的必要。β_2 很接近 1 时，$\boldsymbol{s}$ 起步慢，未修正的 $m/\sqrt{s}$ 在前几十轮都明显偏大，第 10 轮约为 6.5。修正后系数恒为 1。

变量

- $\boldsymbol{x}^{(t)} \in \mathbb{R}^n$：参数。
- $\boldsymbol{m}^{(t)}, \boldsymbol{s}^{(t)} \in \mathbb{R}^n$：读数的一阶统计与平方统计。
- t：计时器，决定修正因子。
- $\alpha > 0$，$\beta_1, \beta_2 \in [0, 1)$，$\epsilon > 0$：步长、两个衰减系数、稳定项。

初始化　令 $\boldsymbol{m}^{(0)} = \boldsymbol{s}^{(0)} = \boldsymbol{0}$，$t = 0$。例中是贯穿例的三项目标，取 $\alpha = 0.1$，$\beta_1 = 0.9$，$\beta_2 = 0.999$，读取顺序为第 $3, 1, 2$ 项，手算时忽略 ϵ，起点和统计是

$$x^{(0)} = 2, \qquad m^{(0)} = 0, \qquad s^{(0)} = 0.$$

每轮更新　在第 t 轮依次执行：

1. **读取**。在当前点读取 $\hat{\boldsymbol{g}}^{(t)}$。例中第一轮

$$\hat{g}^{(0)} = f_3'(2) = -3.$$

2. **更新统计**。按式 (13.74)计算 $\boldsymbol{m}^{(t+1)}$ 和 $\boldsymbol{s}^{(t+1)}$。例中第一轮

$$m^{(1)} = 0.1 \cdot (-3) = -0.3, \qquad s^{(1)} = 0.001 \cdot 9 = 0.009.$$

3. **修正**。按式 (13.75)计算修正量。例中第一轮

$$\hat{m}^{(1)} = \frac{-0.3}{0.1} = -3, \qquad \hat{s}^{(1)} = \frac{0.009}{0.001} = 9.$$

4. **更新参数**。按式 (13.76)更新，然后 $t \leftarrow t+1$。例中第一轮

$$x^{(1)} = 2 - 0.1 \cdot \frac{-3}{3} = 2.1.$$

第二轮抽到第 1 项，读数和统计是

$$\hat{g}^{(1)} = 5.1, \qquad m^{(2)} = 0.24, \qquad s^{(2)} = 0.035001.$$

两个修正分母是 $1 - 0.81 = 0.19$ 和 $1 - 0.998001 = 0.001999$，于是

$$\hat{m}^{(2)} \approx 1.2632, \qquad \hat{s}^{(2)} \approx 17.509, \qquad \sqrt{\hat{s}^{(2)}} \approx 4.184,$$

参数更新为

$$x^{(2)} = 2.1 - 0.1 \cdot \frac{1.2632}{4.184} \approx 2.0698.$$

第三轮抽到第 2 项，读数和统计是

$$\hat{g}^{(2)} \approx 4.1396, \qquad m^{(3)} \approx 0.6300, \qquad s^{(3)} \approx 0.052102.$$

修正后

$$\hat{m}^{(3)} \approx 2.3246, \qquad \hat{s}^{(3)} \approx 17.385, \qquad \sqrt{\hat{s}^{(3)}} \approx 4.170,$$

参数更新为

$$x^{(3)} \approx 2.0698 - 0.0558 = 2.0141.$$

按预定轮数结束，例中 $T = 3$，最终得到 $x^{(3)} \approx 2.0141$。

修正偏差与优化方向的偏差　修正因子只消除零初始化造成的权重不足，它不说明优化方向没有偏差。在上面的例子中，第二轮开始前 $x^{(1)} = 2.1$，

$f'(2.1) = 2.2$。固定历史后，$m^{(2)}$ 的条件均值是 $0.9\cdot(-0.3)+0.1\cdot 2.2 = -0.05$，修正后的分子的条件均值约为

$$\frac{-0.05}{0.19} \approx -0.263.$$

它的符号甚至与 $f'(2.1)$ 相反，原因是分子包含了上一轮的反向读数。分母还依赖本轮读数，所以式 (13.76)的方向既不是当前梯度的无偏估计，也不是确定矩阵乘以当前梯度。

状态与保证 Adam 的状态包括 $\boldsymbol{x}$、$\boldsymbol{m}$、$\boldsymbol{s}$ 和计时 t。恢复运行时四项都要恢复：只恢复参数会丢失方向记忆；t 错了，修正因子就错了。

Adam 的原始论文给出了凸在线问题的分析，后来发现证明中存在问题，并有反例说明算法在一些凸问题上不收敛，下一小节说明这一点。引用 Adam 的保证时，必须对应具体的问题假设和参数设置，不能把一个具体分析中的结论当成算法的一般性质。

逐坐标缩放的边界 图 13.29用精确梯度比较三种方法。目标是 $f = (x_1^2 + 9x_2^2)/2$，起点 $(9, 1)$。主轴与坐标轴对齐时，AdaGrad 第一步是 $\alpha(1, 1)$，随后逐坐标的尺度抵消了两个方向的曲率差异，到第 60 轮目标值约为 10^{-13}。把目标和起点一起旋转 45°，陡峭方向不再对应一个坐标，AdaGrad 到第 60 轮目标值约为 10^{-8}，下降明显变慢。梯度下降对旋转不变，实线和虚线重合。

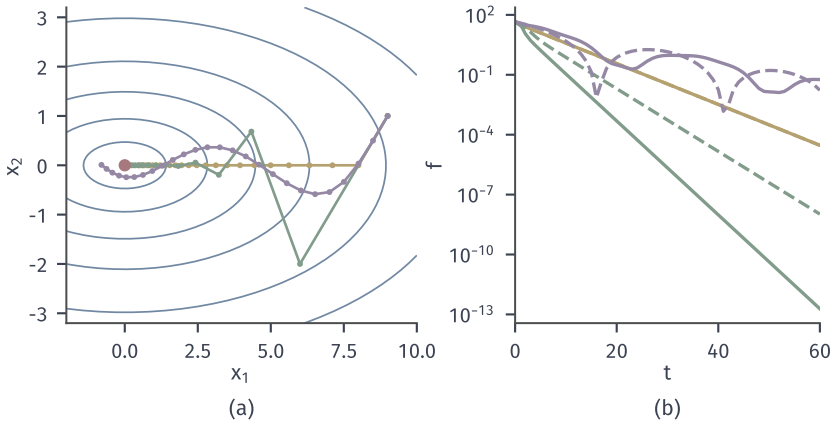


图 13.29 逐坐标缩放与坐标系。目标 $f = (x_1^2 + 9x_2^2)/2$，起点 $(9, 1)$，精确梯度。黄线是 $\alpha = 1/9$ 的梯度下降，绿线是 $\alpha = 3$ 的 AdaGrad，紫线是 $\alpha = 0.5$ 的 Adam $(\beta_1 = 0.9,\ \beta_2 = 0.999)$。(a) 前 25 步的路径。(b) 目标值：实线为原问题，虚线为把目标与起点一起旋转 45° 后的同一问题，两条黄线重合。

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.5.1 AdaGrad
13.5.2 RMSProp
13.5.3 Adam
13.5.4 AMSGrad
13.5.5 AdamW
13.5.6 Adafactor 统计压缩（补充）
13.5.7 Shampoo 矩阵预条件（补充）
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

13.5.4 AMSGrad

分母可能回落 Adam 和 RMSProp 的分母是指数平均，大读数过后可能迅速变小。分母一变小，有效步长就变大，此时的小读数被放大。这会造成什么后果？下面的构造说明，它足以让算法在一个凸问题上走向错误的方向[12]。

可行集是 $[-1,1]$，读数依周期 3 变化，$C>2$：

$$\hat{g}^{(t)}=\begin{cases}C, & t\equiv 1 \pmod 3,\\ -1, & \text{其他.}\end{cases}$$

对应的线性损失为 $f_t(x)=\hat{g}^{(t)}x$，一个周期的总损失是 $(C-2)x$，最优解是 $x=-1$。取 $C=3$，$\beta_1=0$（不用动量），$\beta_2=1/(1+C^2)=0.1$，步长 $\alpha^{(t)}=0.1/\sqrt{t}$，更新后投影回 $[-1,1]$。

一个周期内的净位移 分母的三个值在稳态时循环。s 按式 (13.74)递推，大读数 C 进入时升到约 8.207，之后依次回落到 1.721 和 1.072，所以一个周期的三个除数约为

$$\sqrt{8.207}\approx 2.865,\qquad \sqrt{1.721}\approx 1.312,\qquad \sqrt{1.072}\approx 1.035.$$

三步的位移与步长之比分别是 $-3/2.865$，$+1/1.312$，$+1/1.035$，合计

$$-1.047+0.762+0.966=+0.681>0.$$

一个周期的净位移是正的，迭代被推向错误的边界 $x=+1$。大读数被大分母压低，小读数被回落的分母放大，方向信息就颠倒了。

算法 AMSGrad 让分母只增不减。分子和分母都不作零初始化修正，把历史最大的平方统计放进分母[13]。取 $\bar{\boldsymbol{s}}^{(0)}=\mathbf{0}$，每轮在式 (13.74)之后计算

$$\bar{\boldsymbol{s}}^{(t+1)}=\max\{\bar{\boldsymbol{s}}^{(t)},\boldsymbol{s}^{(t+1)}\},\qquad \boldsymbol{x}^{(t+1)}=\boldsymbol{x}^{(t)}-\alpha^{(t)}\frac{\boldsymbol{m}^{(t+1)}}{\sqrt{\bar{\boldsymbol{s}}^{(t+1)}}+\epsilon},\tag{13.77}$$

其中 max 逐坐标取。

在上面的例子中，$\bar{s}$ 稳定在 8.207，一个周期的位移与步长之比变为

$$\frac{-3+1+1}{2.865}\approx -0.349<0,$$

净位移转为负，迭代走向 $x=-1$。图 13.30的实际运行与此一致：Adam 趋于 $+1$，AMSGrad 趋于 -1。

[12] S. J. Reddi, S. Kale, S. Kumar, *On the Convergence of Adam and Beyond* In International Conference on Learning Representations, 2018

[13] S. J. Reddi, S. Kale, S. Kumar, *On the Convergence of Adam and Beyond* In International Conference on Learning Representations, 2018

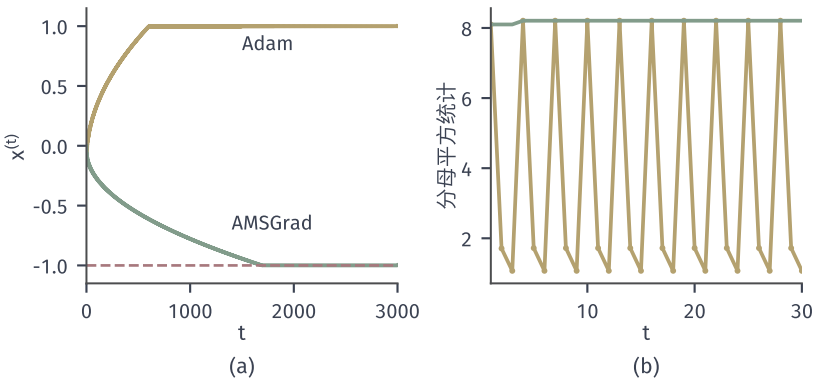


图 13.30 周期线性目标上的 Adam 与 AMSGrad，$C = 3$，$\beta_1 = 0$，$\beta_2 = 0.1$，$\alpha^{(t)} = 0.1/\sqrt{t}$，可行集 $[-1, 1]$。(a) 迭代点，红色虚线是最优解 $x = -1$。(b) 分母中的平方统计：黄线是 Adam 随读数大幅涨落，绿线是 AMSGrad 保持最大值。

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.5.1 AdaGrad
13.5.2 RMSProp
13.5.3 Adam
13.5.4 AMSGrad
13.5.5 AdamW
13.5.6 Adafactor 统计压缩（补充）
13.5.7 Shampoo 矩阵预条件（补充）
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

单调性是代数性质 由更新规则，$\bar{\boldsymbol{s}}^{(t)}$ 逐坐标不减。若基步长 $\alpha^{(t)}$ 不增，则每个坐标的有效缩放系数 $\alpha^{(t)}/(\sqrt{\bar{s}_j^{(t)}} + \epsilon)$ 也不增。

这只是一个代数性质。它不说明目标值下降，也不说明算法收敛。AMSGrad 的在线遗憾界需要凸性、有界可行域、有界读数，以及对 $\beta_1^{(t)}$ 等参数的具体条件[14]。；随机优化和非凸问题上的保证有各自的前提。不同问题上的结论不能互相代替。

[14] S. J. Reddi, S. Kale, S. Kumar, *On the Convergence of Adam and Beyond* In International Conference on Learning Representations, 2018

13.5.5 AdamW

算法 目标中常含平方惩罚 $\frac{\gamma}{2}\|\boldsymbol{x}\|_2^2$。一种处理方式是把惩罚的梯度 $\gamma\boldsymbol{x}$ 加到读数上，送进 Adam 的统计。另一种是**权重衰减**（weight decay）：历史统计只读取原目标的梯度，另外用更新前的参数单独收缩[15]。后一种方法称为 AdamW，统计按式 (13.74)和式 (13.75)计算，参数更新改为

$$\boldsymbol{x}^{(t+1)} = \big(1 - \alpha^{(t)}\gamma\big)\boldsymbol{x}^{(t)} - \alpha^{(t)}\frac{\hat{\boldsymbol{m}}^{(t+1)}}{\sqrt{\hat{\boldsymbol{s}}^{(t+1)}} + \epsilon}. \tag{13.78}$$

[15] I. Loshchilov, F. Hutter, *Decoupled Weight Decay Regularization* In International Conference on Learning Representations, 2019

收缩系数是 $\alpha^{(t)}\gamma$，所以步长调度也带动收缩。对固定步长的随机梯度下降，两种做法相同：

$$\boldsymbol{x} - \alpha(\hat{\boldsymbol{g}} + \gamma\boldsymbol{x}) = (1 - \alpha\gamma)\boldsymbol{x} - \alpha\hat{\boldsymbol{g}}.$$

但 Adam 的方向经过归一化，惩罚的梯度一旦进入统计，它的尺度也被归一化掉，两者不再相同。

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.5.1 AdaGrad
13.5.2 RMSProp
13.5.3 Adam
13.5.4 AMSGrad
13.5.5 AdamW
13.5.6 Adafactor 统计压缩（补充）
13.5.7 Shampoo 矩阵预条件（补充）
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

同一标量首步比较 取 $x^{(0)}=1$，读数 $\hat{g}^{(0)}=-0.1$，$\alpha=0.1$，$\gamma=0.5$，忽略 ϵ。第一轮的归一化方向等于读数的符号。AdamW 用 $\operatorname{sign}(-0.1)=-1$，按式 (13.78)，

$$x^{(1)}=(1-0.05)\cdot 1+0.1=1.05.$$

把惩罚梯度并入读数时，并入后的读数是 $-0.1+0.5\cdot 1=0.4$，符号变成 $+1$，于是

$$x^{(1)}=1-0.1=0.9.$$

两种做法的位移方向相反。图 13.31显示了 γ 变化时的情况：AdamW 的第一步关于 γ 连续变化；并入读数的做法在 $\gamma=0.1$ 处突变，符号翻转后位移就不再随 γ 改变，惩罚的大小被归一化抹去了。

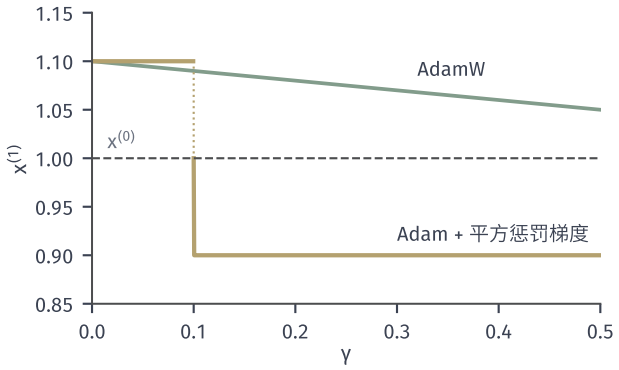


图 13.31 首步 $x^{(1)}$ 关于惩罚系数 γ 的变化，$x^{(0)}=1$，$\hat{g}^{(0)}=-0.1$，$\alpha=0.1$。绿线是 AdamW，黄线是把惩罚梯度并入读数后的 Adam，虚线是起点。

AdamW 与平方惩罚并入读数的做法，优化的不是同一个迭代过程，它们停止的位置一般也不同。评价时要看实际定义的目标：返回点的目标值应写明是否包含惩罚项，收缩系数 γ 的含义也要随之说明。

13.5.6 Adafactor 统计压缩（补充）

用行列边际近似平方统计 参数是矩阵 $\boldsymbol{W}\in\mathbb{R}^{m\times d}$ 时，Adam 的平方统计要存 md 个数。Adafactor 只存平方统计的行和 $\boldsymbol{r}\in\mathbb{R}^{m}$ 与列和 $\boldsymbol{c}\in\mathbb{R}^{d}$，需要时重建近似的平方统计[16]。

设完整的平方统计是 $\boldsymbol{V}$，$\boldsymbol{r}=\boldsymbol{V}\mathbf{1}_d$，$\boldsymbol{c}=\boldsymbol{V}^{\top}\mathbf{1}_m$。假定 $\boldsymbol{V}$ 接近秩一，重建公式是

$$\hat{\boldsymbol{V}}=\frac{\boldsymbol{r}\boldsymbol{c}^{\top}}{\mathbf{1}_m^{\top}\boldsymbol{r}}. \tag{13.79}$$

分母是 $\boldsymbol{V}$ 所有元素的和，这一归一化使重建保持行和与列和：$\hat{\boldsymbol{V}}\mathbf{1}_d=\boldsymbol{r}$，$\hat{\boldsymbol{V}}^{\top}\mathbf{1}_m=\boldsymbol{c}$。存储量从 md 降到 $m+d$。

[16] N. Shazeer, M. Stern, *Adafactor: Adaptive Learning Rates with Sublinear Memory Cost* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 4596–4604

更新的次序 一轮的次序是：先在读数的平方上加稳定项 ϵ_1，得到 $\hat{\boldsymbol{G}}^{(t)} \odot \hat{\boldsymbol{G}}^{(t)} + \epsilon_1$，保证重建的分母为正；再分别用其行和与列和更新 $\boldsymbol{r}$、$\boldsymbol{c}$ 的移动平均；然后由式 (13.79)重建 $\hat{\boldsymbol{V}}$；再求方向 $\boldsymbol{Y} = \hat{\boldsymbol{G}}^{(t)} / \sqrt{\hat{\boldsymbol{V}}}$，把方向按均方根裁剪，最后乘以相对步长更新参数。相对步长与参数自身的均方根成正比，并有下界 ϵ_2。

这三件事分开算：统计压缩改变了尺度的来源，方向裁剪改变了方向的大小，相对步长改变了位移的量纲。评价改动带来的差别时，也要分别考虑。

保留与丢失的信息 重建精确的条件很简单。若 $\boldsymbol{V}$ 元素全为正，$\hat{\boldsymbol{V}} = \boldsymbol{V}$ 当且仅当 $\boldsymbol{V}$ 秩为一，因为 $\hat{\boldsymbol{V}}$ 按构造秩为一。例如

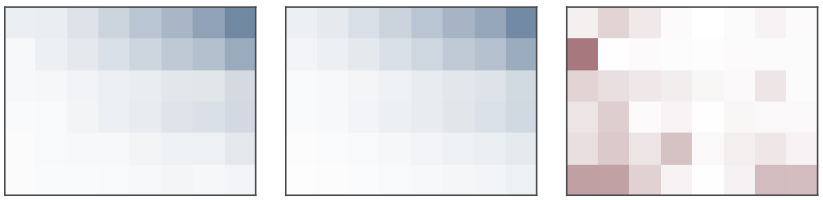
$$\boldsymbol{V} = \begin{bmatrix} 1 & 2 \\ 3 & 6 \end{bmatrix}$$

秩为一，行和是 $(3, 9)$，列和是 $(4, 8)$，总和是 12，重建给出原矩阵。而

$$\boldsymbol{V} = \begin{bmatrix} 4 & 1 \\ 1 & 4 \end{bmatrix}$$

的行和、列和都是 $(5, 5)$，重建得到所有元素都是 2.5 的矩阵，对角线上的大值和非对角线的小值被抹平。

图 13.32给出一个 6×8 的例子。大尺度的行列结构被保留，逐元素的相对误差平均约为 0.13，最大约为 0.70。



(a) (b) (c)

图 13.32 平方统计的行列压缩。(a) 由 40 个随机读数算出的逐元素平方平均 $\boldsymbol{V}$，形状 6×8。(b) 按式 (13.79)由 6 个行和与 8 个列和重建的 $\hat{\boldsymbol{V}}$。(c) 逐元素相对误差。颜色越深数值越大。

压缩减少的只是统计的存储。参数、读数和方向仍是 md 个数；总计算量不会因此变成 $O(m + d)$。低存储也不意味着收敛更快，近似的统计改变了方向，效果要回到目标上评价。

13.5.7 Shampoo 矩阵预条件（补充）

左右 Gram 统计 逐坐标的尺度无法描述“某几行一起变化”这样的方向关系。Shampoo 为矩阵参数维护左右两个 Gram 统计，分别刻画行空间和列空间方向的历史幅度[17]。取 $\epsilon > 0$，$\boldsymbol{L}^{(0)} = \epsilon \boldsymbol{I}_m$，$\boldsymbol{R}^{(0)} = \epsilon \boldsymbol{I}_d$，读取矩阵读数 $\hat{\boldsymbol{G}}^{(t)}$ 后先更新统计：

$$\boldsymbol{L}^{(t+1)} = \boldsymbol{L}^{(t)} + \hat{\boldsymbol{G}}^{(t)} \hat{\boldsymbol{G}}^{(t)\top}, \qquad \boldsymbol{R}^{(t+1)} = \boldsymbol{R}^{(t)} + \hat{\boldsymbol{G}}^{(t)\top} \hat{\boldsymbol{G}}^{(t)}, \tag{13.80}$$

再用两侧的负四分之一次幂更新：

$$\boldsymbol{W}^{(t+1)} = \boldsymbol{W}^{(t)} - \alpha \big(\boldsymbol{L}^{(t+1)}\big)^{-1/4} \hat{\boldsymbol{G}}^{(t)} \big(\boldsymbol{R}^{(t+1)}\big)^{-1/4}. \tag{13.81}$$

ϵ 使两个统计正定，负四分之一次幂才有定义。按正交对角化计算：

$$\boldsymbol{L} = \boldsymbol{Q}\,\mathrm{diag}(\lambda_j)\boldsymbol{Q}^\top \quad \Longrightarrow \quad \boldsymbol{L}^{-1/4} = \boldsymbol{Q}\,\mathrm{diag}\big(\lambda_j^{-1/4}\big)\boldsymbol{Q}^\top.$$

正交对角化可参考卷二第 6 章“谱分解”。这两个矩阵是读数的累计，不是目标的 Hessian。

单步：奇异值被拉平 取 $\epsilon \to 0$，方阵可逆读数 $\boldsymbol{G} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$。则 $\boldsymbol{G}\boldsymbol{G}^\top = \boldsymbol{U}\boldsymbol{\Sigma}^2\boldsymbol{U}^\top$，$\boldsymbol{G}^\top\boldsymbol{G} = \boldsymbol{V}\boldsymbol{\Sigma}^2\boldsymbol{V}^\top$，代入式 (13.81)，

$$\big(\boldsymbol{G}\boldsymbol{G}^\top\big)^{-1/4} \boldsymbol{G} \big(\boldsymbol{G}^\top\boldsymbol{G}\big)^{-1/4} = \boldsymbol{U}\boldsymbol{\Sigma}^{-1/2}\boldsymbol{\Sigma}\boldsymbol{\Sigma}^{-1/2}\boldsymbol{V}^\top = \boldsymbol{U}\boldsymbol{V}^\top.$$

一步的效果与 Muon 的理想极因子相同，所有奇异值都变成 1。例如 $\boldsymbol{G} = \mathrm{diag}(4, 1/4)$ 时，两侧的变换都是 $\mathrm{diag}(1/2, 2)$，变换后得到 $\boldsymbol{I}$，两个方向相差 16 倍的幅度被拉平。

累积多步之后不再这样简单。统计综合了历史上各方向的幅度，变换后的奇异值不等于 1，并且随累积的读取逐渐减小，图 13.33(b) 显示了这一点。这是累计式缩放的共同特点，与 AdaGrad 的有效系数逐渐减小相同。

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.5.1 AdaGrad
13.5.2 RMSProp
13.5.3 Adam
13.5.4 AMSGrad
13.5.5 AdamW
13.5.6 Adafactor 统计压缩（补充）
13.5.7 Shampoo 矩阵预条件（补充）
13.6 梯度的处理
13.7 误差与计算成本
13.8 本章小结

[17] V. Gupta, T. Koren, Y. Singer, *Shampoo: Preconditioned Stochastic Tensor Optimization* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1842–1850

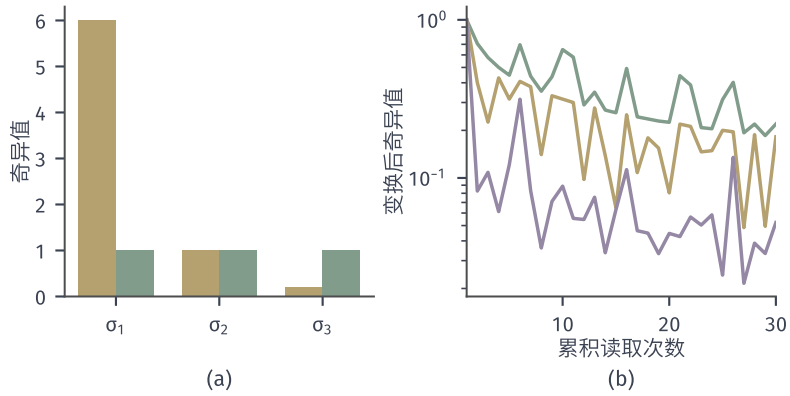


图 13.33 Shampoo 的奇异值变换，$\epsilon = 10^{-6}$，$\boldsymbol{G}$ 是 3×3 矩阵，奇异值为 $6, 1, 0.2$。(a) 单步：原始奇异值（黄）与式 (13.81)变换后的奇异值（绿）。(b) 累积读取时，变换后的三个奇异值随读取次数的变化，读数的各方向幅度随机变化。

计算成本 Shampoo 的额外成本比逐坐标方法高得多。统计的存储是 $O(m^2 + d^2)$；形成两个 Gram 矩阵需要 $O(m^2 d + m d^2)$ 次运算；稠密谱分解求矩阵根一次约 $O(m^3 + d^3)$；两侧作用变换是 $O(m^2 d + m d^2)$。

求根最贵，实际实现常隔若干步才重新计算根，中间继续使用旧因子。这样本轮使用的尺度来自若干步之前的统计，与式 (13.81)“先更新后使用”不是同一个算法，记录时要写明刷新频率。比较方法时，统计存储、分解、旧因子的使用以及每步的乘法都要计入，不能只比较更新次数。

13.6 梯度的处理

前两节的方向都由读数线性组合或缩放而来。本节研究更直接的改动：读数被截短、用有限精度算出、来自过去的点，甚至换成一个人为规定的向量。这些操作都使实际方向偏离原目标的梯度。

实际方向在什么点上、以什么误差近似当前梯度，这个误差怎样影响原目标上的进展？回答时把实际读数分解成三部分：真梯度 $\boldsymbol{g}^{(t)}$、由历史确定的条件偏差 $\boldsymbol{b}^{(t)}$、零条件均值的噪声 $\boldsymbol{\xi}^{(t)}$，

$$\hat{\boldsymbol{g}}^{(t)} = \boldsymbol{g}^{(t)} + \boldsymbol{b}^{(t)} + \boldsymbol{\xi}^{(t)}, \qquad \mathbb{E}\big[\boldsymbol{\xi}^{(t)} \mid \mathcal{F}^{(t)}\big] = \mathbf{0}. \tag{13.82}$$

这个分解在前面的读数误差分析中已经用过，这里偏差项不再为零。下面分别看裁剪、近似和替代三种情形下 $\boldsymbol{b}^{(t)}$ 从哪里来、能否被控制。

13.6.1 梯度裁剪

两种裁剪 梯度裁剪（gradient clipping）在读数过大时把它截短，防止个别很大的读数把参数推得太远[18]。给定阈值 $c > 0$，有两种做法。逐坐标裁

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.6.1 梯度裁剪
13.6.2 近似梯度
13.6.3 替代梯度（补充）
13.7 误差与计算成本
13.8 本章小结

[18] R. Pascanu, T. Mikolov, Y. Bengio, *On the Difficulty of Training Recurrent Neural Networks* In Proceedings of the 30th International Conference on Machine Learning, 2013, pp. 1310–1318

剪（coordinate-wise clipping）把每个坐标截到 $[-c, c]$ 内：

$$\left[\mathrm{clip}_c^{\mathrm{co}}(\boldsymbol{g})\right]_j = \max\{-c, \min\{c, g_j\}\}. \tag{13.83}$$

范数裁剪（norm clipping）整体缩放，只在范数超过阈值时起作用：

$$\mathrm{clip}_c(\boldsymbol{g}) = \boldsymbol{g} \cdot \min\left\{1, \frac{c}{\|\boldsymbol{g}\|_2}\right\}. \tag{13.84}$$

下面用同一个读数比较。取 $\boldsymbol{g} = (3, 4)$，$c = 1$，两种裁剪的结果是

$$\mathrm{clip}_1^{\mathrm{co}}(\boldsymbol{g}) = (1, 1), \qquad \mathrm{clip}_1(\boldsymbol{g}) = (0.6, 0.8).$$

前者的范数是 $\sqrt{2}$，方向从与第一坐标轴夹角约 53° 变成 45°；后者的范数是 1，方向不变。图 13.34(a) 表明，逐坐标裁剪是投影到边长 $2c$ 的正方形，范数裁剪是投影到半径 c 的圆盘。

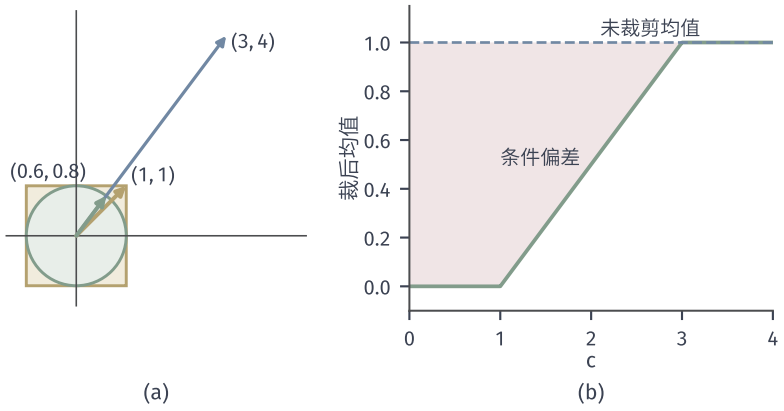


图 13.34 裁剪的几何与偏差。(a) 读数 $(3, 4)$（蓝）在 $c = 1$ 时的两种裁剪：逐坐标裁剪得到黄色正方形角上的 $(1, 1)$；范数裁剪沿原方向缩到绿色圆上的 $(0.6, 0.8)$。(b) 读数以相等概率取 3 或 -1，绿线是逐点裁剪后的均值关于阈值 c 的变化，蓝色虚线是未裁剪的均值 1，红色区域是两者之差。

裁剪放在哪里 一个算法中可以裁剪的位置不止一处，图 13.35标出了四处。裁剪位置 1：裁剪逐样本读数后再平均，后面的动量和统计看到的都是裁过的量。裁剪位置 2：先平均再裁剪批量读数。裁剪位置 3：裁剪动量方向，统计仍记录原始读数。裁剪位置 4：裁剪缩放后的方向，也就是最终的位移。

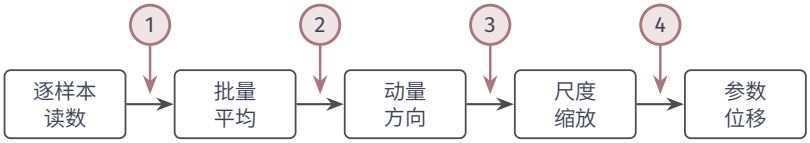


图 13.35 更新流水线上可以施加裁剪的四个位置，圆圈内的数字对应正文的编号。位置不同，得到的是不同的算法，描述一次运行时要写明位置和阈值。

位置 1 和位置 2 的差别，用贯穿例在 $x = 2$ 处的三项读数说明。取 $c = 2$，全批量读数 $5, 4, -3$。先逐项裁剪再平均，得到

$$\frac{1}{3}\big(2 + 2 - 2\big) = \frac{2}{3}.$$

先平均再裁剪，平均是 $f'(2) = 2$，未超过阈值，裁剪不起作用，得到 2。前者有偏差，后者这里没有。

增大批量能否减小偏差，也取决于位置。逐样本裁剪后再平均，批量越大，平均越接近裁后读数的均值，偏差不随批量变小。先平均再裁剪时，批量越大，平均读数越集中在真梯度附近，只要真梯度的范数小于阈值，被裁剪的概率就越小，偏差随之减小。

用两点分布核对偏差 裁剪是非线性运算，它改变读数的平均。设读数以相等概率取 3 与 -1，均值为 1。用 $c = 1$ 裁剪后，读数变为 1 与 -1，均值为 0：

$$\mathbb{E}\big[\mathrm{clip}_1(\hat{g})\big] = 0 \neq 1.$$

条件偏差是 -1，等于真梯度的相反数，方向信息完全消失。图 13.34(b) 画出裁后均值随阈值的变化：$c < 1$ 时为 0，$1 \le c < 3$ 时为 $(c-1)/2$，$c \ge 3$ 时才恢复为 1。

所以裁后的读数不能当作无偏梯度套用前面的定理。贯穿例能说明后果。取 $c = 2$ 的逐项裁剪，期望方向在 $x = 0$ 处为

$$\frac{1}{3}\big(\mathrm{clip}_2(3) + \mathrm{clip}_2(0) + \mathrm{clip}_2(-9)\big) = \frac{1}{3}(2 + 0 - 2) = 0.$$

也就是说，逐项裁剪的均值在 $x = 0$ 处恰好为零，而真正的最优点是 $x^\star = 1$，$f(0) - f^\star = 1$。裁剪把期望更新的平衡点从 $x = 1$ 移到了 $x = 0$。

分别评价两种作用 裁剪的作用要分开评价。第一是控制位移：范数裁剪在位置 2 或位置 4 保证每步位移的范数不超过 αc，这是确定的。第二是控制二阶矩：裁后读数的范数不超过 c，所以它的二阶矩不超过 c^2。原读数的二阶矩很大甚至无穷时，裁剪之后前面依赖方差假设的分析才可能使用。

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.6.1 梯度裁剪
13.6.2 近似梯度
13.6.3 替代梯度（补充）
13.7 误差与计算成本
13.8 本章小结

这两种好处的代价是偏差 $\boldsymbol{b}^{(t)}$。偏差怎样影响进展，由下一小节的递推回答。是否值得用偏差换取有界的二阶矩，要看具体的读数分布，没有无条件的结论。

13.6.2 近似梯度

几种来源 实际得到的方向常常不是当前点的精确读数。下面三种情形都先问两件事：方向在哪个求值点上计算，误差能否由计算预算或步长控制。

第一是有限精度。例如浮点运算或内层线性方程只解到某个残差，读到的是 $\nabla f(\boldsymbol{x}^{(t)})$ 的近似，误差 $\boldsymbol{b}^{(t)}$ 的大小由内层的求解精度决定，增加每步计算可以使它变小。第二是量化，把读数的每个分量化到间距 Δ 的格点上，$|b_j| \le \Delta/2$，这是确定的偏差。真梯度比半个格子还小时，量化后的读数恰好是零，迭代会停在一个有残差的点上。第三是延迟读取，在第 t 轮用 τ 轮之前的点上的梯度 $\nabla f(\boldsymbol{x}^{(t-\tau)})$，也就是求值点不是当前点。

延迟的误差由步长控制，但可能破坏稳定性。设 $f(x)=\tfrac{1}{2}x^2$，用延迟 $\tau=1$ 的精确梯度，

$$x^{(t+1)} = x^{(t)} - \alpha x^{(t-1)}.$$

特征方程是 $r^2 - r + \alpha = 0$。当 $\alpha \in (0,1)$ 时，两根的模都小于 1：两根为实数时积为 α，和为 1，都在 $(0,1)$ 内；两根共轭时模的平方等于积 α。当 $\alpha = 1$ 时两根落在单位圆上，迭代恰好以周期 6 循环。没有延迟时，α 可以取到 2，所以延迟把稳定的步长范围缩小了一半。图 13.36(b) 是 $\alpha = 1$ 的情形，$\tau = 2$ 时发散。

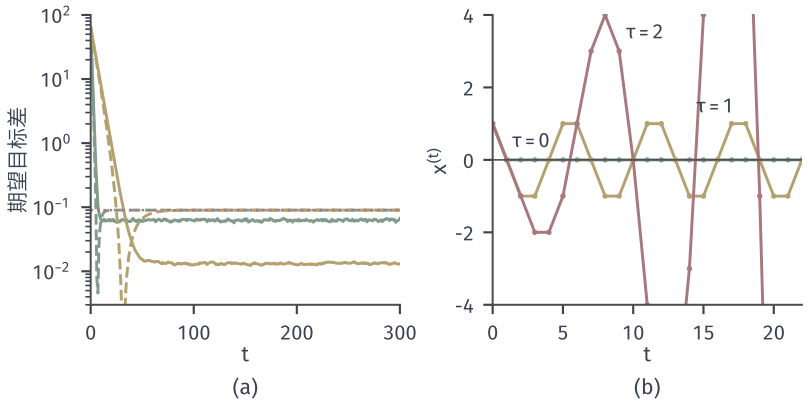


图 13.36 偏差、噪声与延迟的影响。(a) 目标 $f(x)=(x-1)^2+5$，初值 $x=9$，2000 次独立运行的平均目标差，绿线 $\alpha=0.2$，黄线 $\alpha=0.05$。实线是只有方差为 1 的噪声；虚线是只有常数偏差 $b=0.6$，两种步长最终都停在红色点线 $b^2/4=0.09$ 上。(b) 目标 $\tfrac{1}{2}x^2$，$\alpha=1$，延迟 $\tau=0,1,2$ 的迭代点。

把偏差和噪声代入递推 现在按式 (13.82)把两类误差代入有限步递推。下面的结果与前面的无偏分析结构相同，只多了偏差产生的一项。

定理 13.14 有偏读数下的平均平方梯度范数 设 f 梯度 L-Lipschitz 连续，下确界为 $f_{\inf}$。设读数满足式 (13.82)，其中 $\boldsymbol{b}^{(t)}$ 由 $\mathcal{F}^{(t)}$ 确定，并且

$$\|\boldsymbol{b}^{(t)}\|_2 \le B, \qquad \mathbb{E}\big[\|\boldsymbol{\xi}^{(t)}\|_2^2 \mid \mathcal{F}^{(t)}\big] \le \sigma^2. \tag{13.85}$$

取固定步长 $0 < \alpha \le 1/L$，用 $\hat{\boldsymbol{g}}^{(t)}$ 代替梯度做一步更新。则

$$\mathbb{E}\big[f(\boldsymbol{x}^{(t+1)}) \mid \mathcal{F}^{(t)}\big] \le f(\boldsymbol{x}^{(t)}) - \frac{\alpha}{2}\|\boldsymbol{g}^{(t)}\|_2^2 + \frac{\alpha}{2}B^2 + \frac{L\alpha^2}{2}\sigma^2, \tag{13.86}$$

因而

$$\frac{1}{T}\sum_{t=0}^{T-1}\mathbb{E}\|\boldsymbol{g}^{(t)}\|_2^2 \le \frac{2\big(f(\boldsymbol{x}^{(0)}) - f_{\inf}\big)}{\alpha T} + B^2 + L\alpha\sigma^2. \tag{13.87}$$

证明 由下降引理，

$$f(\boldsymbol{x}^{(t+1)}) \le f(\boldsymbol{x}^{(t)}) - \alpha\langle \boldsymbol{g}^{(t)}, \hat{\boldsymbol{g}}^{(t)}\rangle + \frac{L\alpha^2}{2}\|\hat{\boldsymbol{g}}^{(t)}\|_2^2.$$

记 $\boldsymbol{a} = \boldsymbol{g}^{(t)} + \boldsymbol{b}^{(t)}$，它由历史确定。固定 $\mathcal{F}^{(t)}$ 取条件期望。噪声的条件均值为零，所以交叉项消失，

$$\mathbb{E}\langle \boldsymbol{g}^{(t)}, \hat{\boldsymbol{g}}^{(t)}\rangle = \langle \boldsymbol{g}^{(t)}, \boldsymbol{a}\rangle, \qquad \mathbb{E}\|\hat{\boldsymbol{g}}^{(t)}\|_2^2 \le \|\boldsymbol{a}\|_2^2 + \sigma^2.$$

由 $\alpha \le 1/L$，$L\alpha^2/2 \le \alpha/2$，于是 $\|\boldsymbol{a}\|_2^2$ 前的系数可以放大到 $\alpha/2$，得到

$$\mathbb{E}f(\boldsymbol{x}^{(t+1)}) \le f(\boldsymbol{x}^{(t)}) - \alpha\langle \boldsymbol{g}^{(t)}, \boldsymbol{a}\rangle + \frac{\alpha}{2}\|\boldsymbol{a}\|_2^2 + \frac{L\alpha^2}{2}\sigma^2.$$

展开平方并配方，

$$-\alpha\langle \boldsymbol{g}^{(t)}, \boldsymbol{a}\rangle + \frac{\alpha}{2}\|\boldsymbol{a}\|_2^2 = \frac{\alpha}{2}\big(\|\boldsymbol{a} - \boldsymbol{g}^{(t)}\|_2^2 - \|\boldsymbol{g}^{(t)}\|_2^2\big) = \frac{\alpha}{2}\big(\|\boldsymbol{b}^{(t)}\|_2^2 - \|\boldsymbol{g}^{(t)}\|_2^2\big).$$

代入 $\|\boldsymbol{b}^{(t)}\|_2 \le B$，得到式 (13.86)。对 $t = 0, \dots, T-1$ 取全期望并累加，用 $f(\boldsymbol{x}^{(T)}) \ge f_{\inf}$，两边除以 $\alpha T/2$，得到式 (13.87)。 ■

式 (13.87)有三项。第一项是初始误差，随 T 消失。第三项是噪声，正比于 α，可以用小步长或小批量压低。第二项 B^2 既不依赖 α，也不依赖 T。

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.6.1 梯度裁剪
13.6.2 近似梯度
13.6.3 替代梯度（补充）
13.7 误差与计算成本
13.8 本章小结

图 13.36(a) 验证了这一分工。只有噪声时，α 从 0.2 减到 0.05，平台约从 0.0625 降到 0.0132，与 $\alpha/(2(2-2\alpha))$ 一致。只有常数偏差时，两种步长最终停在同一高度 $b^2/4 = 0.09$，小步长只是到达得更慢。

上界中的残余不是下限 B^2 是上界中的项，不是误差的下限。偏差项能否真的造成残余，取决于偏差的结构。

设 $f(x) = \frac{1}{2}x^2$，常数偏差 b 使读数的均值变成 $x + b$，迭代的平衡点是 $x = -b$，平方梯度是 b^2，这时界是紧的。如果偏差随梯度变小，满足

$$\|\boldsymbol{b}^{(t)}\|_2 \le \rho\|\boldsymbol{g}^{(t)}\|_2, \qquad \rho < 1,$$

回到证明中的配方等式，确定部分的下降量至少是 $\frac{\alpha}{2}(1-\rho^2)\|\boldsymbol{g}^{(t)}\|_2^2$，平方梯度可以趋于零。裁剪在读数范数以概率 1 小于阈值时偏差恰好为零，这时实际残余也小于用 B^2 估计的量。

13.6.3 替代梯度（补充）

导数没有用处的前向函数 前向函数有时是分段常数，经典梯度几乎处处为零。设 $Q(w) = \lfloor w + \frac{1}{2} \rfloor$ 是取整，损失为

$$F(w) = \frac{1}{2}\big(Q(w) - a\big)^2. \tag{13.88}$$

Q 在非半整数点局部为常数，所以除了可数个跳跃点外 $F'(w) = 0$，导数不提供任何信息。梯度下降一步也不会动。

人为指定的反向规则 **直通估计**（straight-through estimator）在反向计算时假装 Q 是恒等映射，规定 $\mathrm{d}Q/\mathrm{d}w = 1$[19]。，返回的方向是

$$g_{\mathrm{STE}}(w) = Q(w) - a. \tag{13.89}$$

这类人为指定的方向统称**替代梯度**（surrogate gradient）。要区分两件事：前向函数 F 是实际被评价的对象，反向规则是另外选的方向生成方式，两者之间没有求导关系。在计算图中还常用**停止梯度**（stop-gradient）这一传播规则写成 $w + \mathrm{sg}(Q(w) - w)$，其中 sg 前向原样传值，反向阻断传播；前向得到 $Q(w)$，反向等于恒等映射。它是计算图上的规则，不是数学运算的导数。

[19] Y. Bengio, N. Léonard, A. Courville, *Estimating or Propagating Gradients Through Stochastic Neurons for Conditional Computation* In arXiv preprint arXiv:1308.3432, 2013

跨阈值的两次更新 图 13.37给出同一点出发的两个结果。取 $w = 0.3$，此时 $Q(w) = 0$。若 $a = 1$，损失是 $F = 0.5$，替代方向是 -1，取步长 0.4 走到 $w = 0.7$，此时 $Q = 1$，损失降到

$$F(0.7) = \frac{1}{2}(1-1)^2 = 0.$$

若 $a = 0.3$，损失是 $F = 0.045$，替代方向是 -0.3，取步长 $4/3$ 同样走到 $w = 0.7$，损失却升到

$$F(0.7) = \frac{1}{2}(1-0.3)^2 = 0.245.$$

光滑情形下的下降依赖于“小步之内一阶模型准确”，而跨过跳跃点时一阶模型完全失效。所以无法从替代方向推出下降。

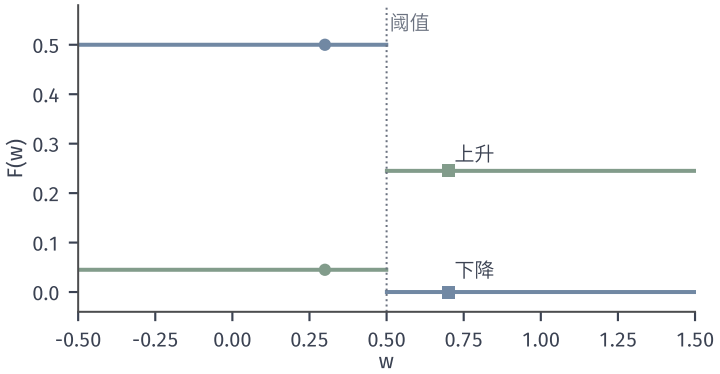


图 13.37 取整前向上的直通更新。蓝线 $F(w) = \frac{1}{2}(Q(w)-1)^2$，绿线 $F(w) = \frac{1}{2}(Q(w)-0.3)^2$，都是分段常数，点线是取整阈值 $w = 0.5$。圆点是起点 $w = 0.3$，方块是走一步后的 $w = 0.7$：蓝色的损失由 0.5 降到 0，绿色的损失由 0.045 升到 0.245。

替代方向的地位 替代方向既不是原目标的经典梯度，一般也不是凸次梯度。以 $a = 1$，$w = 0.3$ 为例，若 s 是全局次梯度，要求不等式 $F(y) \geq F(0.3) + s(y - 0.3)$ 对一切 y 成立。

取 $y = 0.7$, 得到 $0 \geq 0.5 + 0.4s$, 即 $s \leq -1.25$。取 $y = -0.4$, $F(-0.4) = 0.5$, 得到 $s \geq 0$。两者矛盾，这样的 s 不存在，F 在该点没有全局次梯度，-1 更不是。局部上 F 在该点附近为常数，局部的次梯度只有 0，也不是 -1。

所以使用替代方向的算法，只能回到实际的前向目标上评价。比较的量应是前向损失或原问题的目标值，停止准则也应基于前向量，而不是替代方向的范数是否变小。

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.7.1 误差的评价对象
13.7.2 总计算成本
13.7.3 样本替换的有限步响应
13.8 本章小结

13.7 误差与计算成本

本章已经出现了很多方法，每一种都有自己的误差界和成本描述。它们能不能放在一起比较？回答这个问题，先要固定三件事：要最小化哪个目标，算法返回什么，用什么量计算成本。本节依次讨论评价对象、总计算成本，以及当输入的数据发生变化时算法的有限步响应。

13.7.1 误差的评价对象

量与返回点的配对 一个收敛结论由两部分组成：度量什么量，度量哪个点。常用的量有目标差、到最小点的距离、梯度范数或邻近残差；常用的返回点有最后一点、平均点和随机返回点。量和点的配对不能互换，表 13.5列出常见的配对。

表 13.5 常见的误差量与返回点的配对。条件只列出主要假设，具体常数和步长以相应结论为准。

误差量	返回点	主要条件
期望目标差	加权平均点	凸
期望目标差	最后一点	强凸
到最小点的距离	最后一点	强凸
平方梯度范数	按权重随机返回	光滑非凸
邻近残差	按权重随机返回	复合目标

配对的差别可以在贯穿例上看见。常步长 $\alpha = 0.1$ 时，随机梯度下降的最后一点的期望目标差趋于 0.528，不随轮数继续下降。模拟 20 万条路径，后 2000 轮的平均点的期望目标差约为 0.0024，比最后一点小两个多量级。平均减小了噪声，但关于平均点的界不能直接移用到某个单独的迭代点上。

期望保证与概率保证 上面的误差界都是期望。期望小不等于每次运行都小。若 $Z \ge 0$ 是目标差，$\mathbb{E}Z \le \varepsilon$，由 Markov 不等式，对任意 $\delta \in (0,1)$，

$$\mathbb{P}\left(Z \ge \frac{\varepsilon}{\delta}\right) \le \delta. \tag{13.90}$$

比如 $\mathbb{E}Z \le 0.01$，只能得到目标差超过 0.1 的概率不超过 0.1。这里 ε/δ 随 δ 变小放大得很快。更强的高概率保证需要读数的尾部条件，例如有界或次高斯，并使用鞅集中不等式，推导要用到鞅的工具，这里只说明它与期望保证的区别。

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.7.1 误差的评价对象
13.7.2 总计算成本
13.7.3 样本替换的有限步响应
13.8 本章小结

路径的长期性质是另一个问题，例如一条路径是否几乎必然收敛，这类结论依赖步长条件和鞅收敛定理，属于前面提到的长期路径分析。有限步的期望界不能回答这个问题。

各类误差进入递推的位置 本章遇到的误差进入递推的不同位置。条件噪声进入二次项，贡献 σ^2 乘以步长的相应幂次，能靠减小步长或增大批量压低。系统偏差进入一次项，贡献的 B^2 不随步长变小。近似求解的误差与偏差类似，由内层精度决定。

这些都是**优化误差**（optimization error），针对的是给定的目标。如果目标是由一批样本构造的有限和，而真正关心的是总体上的目标，那么还有一部分由样本有限造成的差距。这部分属于统计误差，优化再精确也不能消除，分析它需要样本数和分布条件。优化误差不能代替统计误差，反过来也一样。

13.7.2 总计算成本

统一单位 比较方法之前，先把计量单位统一下来。常用的单位有样本梯度读取次数、参数更新次数、完整遍历次数。一次全梯度是 N 次样本梯度读取；一轮批量大小为 b 的小批量是 b 次读取、一次更新。此外要把快照、梯度表、矩阵分解、邻近求解、同步统计这些额外工作计入。

下面的估计都假定目标在同一种归一化下，要求同一个精度 ε，略去常数因子。设 f 是 N 项的平均，强凸常数 μ，整体光滑常数 L，逐项光滑常数最大值 $L_{\max}$，$\kappa_{\max}=L_{\max}/\mu$，读数方差 σ^2。

表 13.6 强凸有限和目标上达到目标差 ε 的样本梯度读取量，略去常数因子。

方法	读取量	额外状态
全梯度下降	$N\kappa\ln(1/\varepsilon)$	无
随机梯度下降	$\sigma^2/(\mu\varepsilon)$	无
SVRG	$(N+\kappa_{\max})\ln(1/\varepsilon)$	一个快照
SAGA	$(N+\kappa_{\max})\ln(1/\varepsilon)$	梯度表，N 份

用具体数比较。取 $N=1000$，$\kappa=\kappa_{\max}=100$，$\sigma^2/\mu=1$。

当 $\varepsilon=10^{-3}$ 时，$\ln(1/\varepsilon)\approx 6.9$，全梯度下降、随机梯度下降和 SVRG 的读取量分别是

$$6.9\times 10^{5},\qquad 1000,\qquad 7.6\times 10^{3},$$

随机梯度下降最便宜。当 $\varepsilon=10^{-6}$ 时，$\ln(1/\varepsilon)\approx 13.8$，三个读取量变成

$$1.4\times 10^{6},\qquad 10^{6},\qquad 1.5\times 10^{4},$$

13.1 随机目标与梯度估计
13.2 随机梯度方法
13.3 方差控制
13.4 随机动量方法
13.5 自适应更新
13.6 梯度的处理
13.7 误差与计算成本
13.7.1 误差的评价对象
13.7.2 总计算成本
13.7.3 样本替换的有限步响应
13.8 本章小结

SVRG 的读取量比随机梯度下降少约 60 倍。结论是：用什么方法取决于要求的精度，低精度时常步长的简单方法足够，高精度时方差减小的方法更划算。

按不同单位，排序不同 图 13.38在同一个最小二乘问题上用两种单位画出四种方法。按参数更新次数，全梯度下降明显最快，因为每次更新读了全部 200 项。按样本读取量，全梯度下降落到后面，SAGA 和随机梯度下降早期下降最快。只按外层轮数排序，或者只按更新次数排序，都会得出不同的结论。

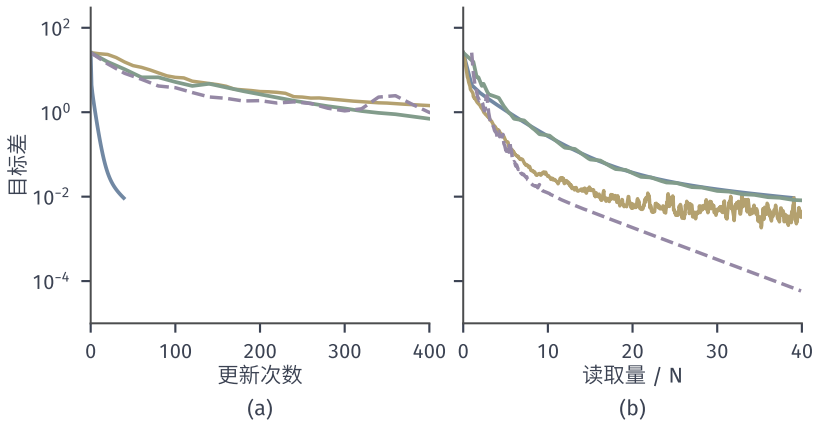


图 13.38 同一个问题按不同单位的进展，有限和最小二乘加平方惩罚，$N = 200$，$n = 10$，$\gamma = 0.1$。蓝线是步长 $1/L$ 的全梯度下降，黄线是常步长随机梯度下降，绿线是 SVRG，紫色虚线是 SAGA。(a) 横轴是参数更新次数。(b) 横轴是样本读取量除以 N，SVRG 的快照和控制变量都计入读取量，SAGA 的梯度表初始化也计入。

批量、微批量与历史更新的计时 计时单位在调度中也要说明。步长调度按更新次数、样本读取量还是遍历次数推进，不同的实现可能相差一个批量大小的倍数。把一个批量拆成微批量累积梯度时，读取量不变，但更新次数减少；若统计量（比如批量内的归一化）按微批量更新，就要规定它的计时。

减少更新次数是否值得增加单步工作，取决于这次工作能否并行、读取是否昂贵、更新本身的成本。计算结论应写成“在某某单位下，某方法达到某精度需要多少”，不能只说某方法更快。

13.7.3 样本替换的有限步响应

问题 前面都固定了目标。现在换一个问题：两份数据只相差一个样本，让同一个算法在两份数据上运行，输出相差多少？这刻画的是算法这个从数据到输出的映射对单个样本有多敏感，称为**算法稳定性**（algorithmic stability）。

设目标 f 由 N 项平均而成，另一份数据的目标 $\tilde f$ 只把第 k 项换成 $\tilde f_k$，其余项相同。两次运行使用相同的初值、相同的步长序列，以及相同的下标路径 $i^{(0)}, i^{(1)}, \dots$，得到 $\boldsymbol{x}^{(t)}$ 和 $\tilde{\boldsymbol{x}}^{(t)}$。这种做法称为耦合，它把抽样噪声的影响去掉，图 13.39展示了它的结构：差异只在抽到第 k 项时产生。

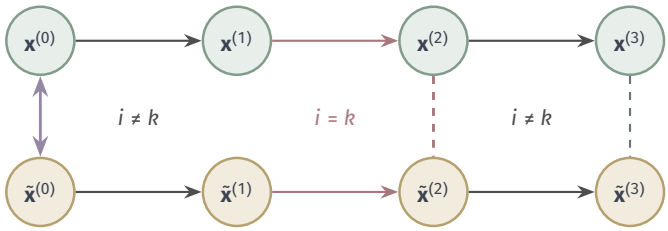


图 13.39　两次耦合运行。两条轨迹起点相同（紫色）。下标 $i \neq k$ 时，两边用同一项更新，只传播已有差异；$i = k$ 时（红色箭头），两边用不同的项更新，新差异在此注入。

用贯穿例计算　取贯穿例，把第 3 项 $f_3 = \frac{3}{2}(x-3)^2$ 换成 $\tilde f_3 = \frac{3}{2}x^2$，也就是 b_3 从 3 变成 0。起点都是 2，$\alpha = 0.1$，读取顺序为第 $3, 1, 2$ 项，其中第一轮抽到被替换的项。两条轨迹依次是

$$\begin{aligned} x^{(1)} &= 2.3, & \tilde x^{(1)} &= 1.4, & |x - \tilde x| &= 0.9, \\ x^{(2)} &= 1.77, & \tilde x^{(2)} &= 0.96, & |x - \tilde x| &= 0.81, \\ x^{(3)} &= 1.416, & \tilde x^{(3)} &= 0.768, & |x - \tilde x| &= 0.648. \end{aligned}$$

第一轮两边的读数分别是 -3 和 6，注入的差异是 $0.1 \cdot 9 = 0.9$。后两轮用相同的项，$a_i = 1, 2$，差异分别乘以 $1 - \alpha a_i = 0.9$ 和 0.8，没有放大。下面的分析把这两种情形一般化。

传播：梯度步的非扩张　先看未抽到被替换项的一步。两边用同一个函数走一步，距离不增加，这由下面的引理保证。这里为了证明简短，假定函数二阶连续可微。

> **引理 13.15　梯度步的非扩张与压缩**　设 ϕ 二阶连续可微，$\mu_0 \boldsymbol{I} \preceq \nabla^2 \phi \preceq L\boldsymbol{I}$，$\mu_0 \geq 0$。若 $0 < \alpha \leq 2/(L + \mu_0)$，则对任意 $\boldsymbol{x}, \boldsymbol{y}$，
>
> $$\big\| \big(\boldsymbol{x} - \alpha \nabla \phi(\boldsymbol{x})\big) - \big(\boldsymbol{y} - \alpha \nabla \phi(\boldsymbol{y})\big) \big\|_2 \leq (1 - \alpha \mu_0) \|\boldsymbol{x} - \boldsymbol{y}\|_2 . \tag{13.91}$$

证明　由微积分基本定理，

$$\nabla \phi(\boldsymbol{x}) - \nabla \phi(\boldsymbol{y}) = \boldsymbol{A}(\boldsymbol{x} - \boldsymbol{y}), \qquad \boldsymbol{A} = \int_0^1 \nabla^2 \phi\big(\boldsymbol{y} + s(\boldsymbol{x} - \boldsymbol{y})\big)\, \mathrm{d}s.$$

$\boldsymbol{A}$ 对称且 $\mu_0 \boldsymbol{I} \preceq \boldsymbol{A} \preceq L\boldsymbol{I}$。于是左端等于 $\|(\boldsymbol{I} - \alpha \boldsymbol{A})(\boldsymbol{x} - \boldsymbol{y})\|_2$，矩阵 $\boldsymbol{I} - \alpha \boldsymbol{A}$ 的特征值落在 $[1 - \alpha L, 1 - \alpha \mu_0]$ 内。条件 $\alpha \le 2/(L + \mu_0)$ 保证 $\alpha L - 1 \le 1 - \alpha \mu_0$，所以这些特征值的绝对值不超过 $1 - \alpha \mu_0$，由此得到结论。 ■

注入与传播的合成　差异只在抽到第 k 项时产生，每一步的概率是 $1/N$。下面的定理把注入和传播合成一个界。

定理 13.16　样本替换下的期望参数距离　设每个 f_i 与 $\tilde{f}_k$ 二阶连续可微，满足 $\boldsymbol{0} \preceq \nabla^2 \preceq L\boldsymbol{I}$。下标独立均匀抽取，确定的步长满足 $0 < \alpha^{(t)} \le 2/L$。设在两条轨迹访问的点上，被替换的两项梯度满足

$$\|\nabla f_k(\boldsymbol{x}^{(t)})\|_2 \le G, \qquad \|\nabla \tilde{f}_k(\tilde{\boldsymbol{x}}^{(t)})\|_2 \le G. \tag{13.92}$$

则

$$\mathbb{E}\|\boldsymbol{x}^{(T)} - \tilde{\boldsymbol{x}}^{(T)}\|_2 \le \frac{2G}{N} \sum_{t=0}^{T-1} \alpha^{(t)}. \tag{13.93}$$

证明　记两条轨迹的距离为

$$\delta^{(t)} = \|\boldsymbol{x}^{(t)} - \tilde{\boldsymbol{x}}^{(t)}\|_2, \qquad \delta^{(0)} = 0.$$

若 $i^{(t)} \ne k$，两条轨迹用同一个 f_i 走一步，由引理 13.15（$\mu_0 = 0$），

$$\delta^{(t+1)} \le \delta^{(t)}.$$

若 $i^{(t)} = k$，由三角不等式和式 (13.92)，

$$\delta^{(t+1)} \le \delta^{(t)} + \alpha^{(t)}\big(\|\nabla f_k(\boldsymbol{x}^{(t)})\|_2 + \|\nabla \tilde{f}_k(\tilde{\boldsymbol{x}}^{(t)})\|_2\big) \le \delta^{(t)} + 2\alpha^{(t)} G.$$

下标与历史独立，后一种情形的条件概率是 $1/N$，所以

$$\mathbb{E}\big[\delta^{(t+1)} \mid \mathcal{F}^{(t)}\big] \le \delta^{(t)} + \frac{2\alpha^{(t)} G}{N}.$$

取全期望，对 $t = 0, \dots, T-1$ 累加，得到式 (13.93)。 ■

这个界的结构是：每步以概率 $1/N$ 注入不超过 $2\alpha^{(t)}G$ 的差异，注入后的差异不再放大。若每项还 μ_0 强凸，$\mu_0 > 0$，$\alpha \le 2/(L+\mu_0)$，引理给出的压缩因子就进入递推，常步长下

$$\mathbb{E}\delta^{(t+1)} \le (1-\alpha\mu_0)\mathbb{E}\delta^{(t)} + \frac{2\alpha G}{N},$$

它的极限不超过 $2G/(N\mu_0)$，界不再随 T 无限增长。图 13.40(b) 显示了实际平均距离与两条界：实际距离上升到约 0.04 后回落并稳定，远低于两条上界。上界偏保守的一个原因是 G 取了路径上的最大值，而实际注入的差异通常小于 $2\alpha G$。

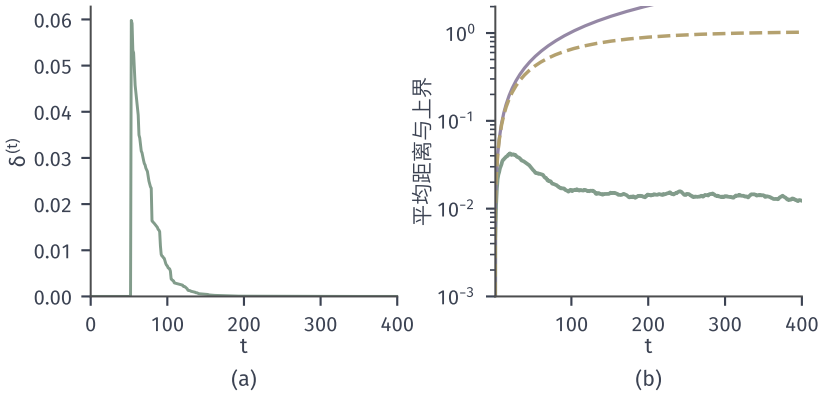


图 13.40　样本替换的有限步响应，平方损失加平方惩罚的 $N = 100$ 项平均，$\gamma = 0.2$，常步长 $1/L_{\max}$，第 1 项被替换。(a) 一条耦合路径上的距离 $\delta^{(t)}$：抽到被替换项时跳起，之后逐渐压缩。(b)1500 对路径的平均距离（绿），式 (13.93)的非扩张界（紫）与利用强凸的压缩界（黄色虚线）。

结论的适用范围　逐项的条件要逐一核对。这里要求的是每一项凸且光滑，只有平均目标凸是不够的，否则未抽到被替换项的那一步也可能拉开距离。凸性和步长决定传播：目标不凸时，梯度步可以把差异放大到 $1+\alpha L$ 倍；步长超过 $2/L$ 时，即使凸函数的梯度步也可能扩张。梯度界 G 只需要在实际访问的点上成立；对最小二乘这样的目标，它依赖轨迹所停留的区域。去掉二阶可微条件时，凸 L 光滑函数的梯度步仍然非扩张，证明需要梯度的余强制性，篇幅较长，读者可查阅[20]。

式 (13.93)说的是参数的距离。要把它转成损失的变化，还需要损失对参数的定量控制：若损失关于参数 K-Lipschitz，则损失之差不超过 $K\|\boldsymbol{x}^{(T)} - \tilde{\boldsymbol{x}}^{(T)}\|_2$。这是另一个独立的条件。从算法的输出差异到统计泛化结论，还要有样本分布和数据生成假设，这部分不在有限步优化的范围内。

[20] M. Hardt, B. Recht, Y. Singer, *Train Faster, Generalize Better: Stability of Stochastic Gradient Descent* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1225–1234

13.8　本章小结

13.1　随机目标与梯度估计
13.2　随机梯度方法
13.3　方差控制
13.4　随机动量方法
13.5　自适应更新
13.6　梯度的处理
13.7　误差与计算成本
13.8　本章小结

本章回答了一个问题：不读全部目标项时，怎样构造更新并判断它的结果。抽样决定读取哪些项，读数的条件无偏是一切分析的起点，但单步读数可能指向上升方向，要靠期望递推和步长控制来管理噪声。

方差控制决定怎样利用额外读取和记忆。小批量、非均匀抽样和控制变量都能减小读数的方差，代价是快照、梯度表或抽样分布的维护。方差减小并不等同于总计算减少，要按相同的目标和精度比较。

动量、自适应尺度和方向处理分别改变实际更新的不同环节。动量把历史读数合成方向，平滑噪声的同时带来滞后，它对当前梯度不是无偏的，常步长下的噪声残余由有效步长决定。Nesterov 方法的读数对应前瞻点，确定性的加速不能直接继承，噪声在势函数中留下不随步数消失的项。Lion 与 Muon 对动量做非线性变换，分别舍弃坐标和奇异方向的幅度，实际位移、原目标残差和矩阵运算成本要分开核对。

自适应方法用历史幅度决定尺度。AdaGrad 累计平方而难以遗忘，RMSProp 用指数平均，Adam 再加上方向平均和零初始化修正，AMSGrad 让分母单调，AdamW 把收缩与统计分开，Adafactor 和 Shampoo 处理矩阵参数的存储和方向关系。这些尺度通常依赖当前读数，每种保证都必须连同它的假设一起引用，单调性之类的代数性质不是收敛结论。

裁剪、近似和替代让实际方向偏离梯度。把读数分解为真梯度、条件偏差和噪声，就能看到噪声项随步长缩小，偏差项不随步长缩小，而上界中的残余不一定是实际的下限。替代方向不是原目标的导数，评价和停止都要回到实际的前向目标。

所有保证都对应一个具体的目标、一个返回点和一个计算单位。同一个问题按更新次数和按读取量计时，方法的排序可以不同。有限步优化误差、路径的长期收敛和样本造成的统计误差是三个不同的问题，本章处理的是第一个，只说明了另外两个与它的分工。样本替换的分析则把算法看作从数据到输出的映射，为后续讨论统计误差提供了一种输入。

随机梯度方法需要目标的梯度读数。若只能读到函数值，就要先由函数值构造方向，下一章研究这个问题。

14.1 函数值反馈
14.1.1 精确函数值与含噪读数
14.1.2 单点查询与成对查询
14.2 有限差分
14.3 随机平滑与梯度估计
14.4 零阶随机梯度方法
14.5 误差与查询成本
14.6 本章小结

第 14 章

零阶随机优化

设想调节一台仿真器的两个参数。把参数填进去，运行一次，仿真器吐出一个代价数字。它的内部是几十万行别人写的程序，没有人能告诉你代价对参数的导数，甚至不确定这个导数处处存在。此前各章每一步都要读梯度，这里没有梯度可读，能做的只是换一组参数再试一次。

这样的处境里，局部方向只能靠函数值的差别来构造。**零阶优化**（zeroth-order optimization）指只使用函数值的优化，“零阶”相对于用梯度的一阶和用 Hessian 的二阶而言。本章讨论其中用随机扰动构造方向的一类方法，称为**零阶随机优化**（zeroth-order stochastic optimization，ZOSO）。全章用同一个目标核对每一步：

$$f(\boldsymbol{x}) = \frac{1}{2}\bigl(x_1^2 + 9x_2^2\bigr), \qquad \boldsymbol{x}^{(0)} = (9, 1). \tag{14.1}$$

它的梯度是 $\nabla f(\boldsymbol{x}) = (x_1, 9x_2)$，$L = 9$，$\mu = 1$，起点处 $f = 45$，$\nabla f = (9, 9)$。这些量只用来检查算法，算法本身看不到表达式，只能读数。

第 14.1节先说清一次查询返回什么，因为后面所有结论都依赖这个接口。第 14.2节用差商逼近原目标的梯度，会遇到两个对手：扰动尺度太大时的截断误差，太小时被放大的读数噪声。第 14.3节换一种看法：不去逼近原梯度，而是把目标在邻域上平均一下，于是函数值能够给出这个平均目标梯度的无偏估计。

有了方向，第 14.4节把它接进迭代，需要分清算法到底在优化哪个目标。第 14.5节按函数读数次数比较各种方法，并回答最后一个问题：在平滑目标上得到的结论，对原目标意味着什么。

14.1 函数值反馈

调节仿真器参数时，算法与仿真器之间到底交换什么信息？同样叫“只能读函数值”，读数是否带噪声、一轮能读几个位置、两次读数能否共用一次仿真，会让后面的误差结论相差几个量级。所以先把接口固定下来。

14.1 函数值反馈
14.1.1 精确函数值与含噪读数
14.1.2 单点查询与成对查询
14.2 有限差分
14.3 随机平滑与梯度估计
14.4 零阶随机梯度方法
14.5 误差与查询成本
14.6 本章小结

目标、查询点与读数 我们要最小化 $f(\boldsymbol{x})$，$\boldsymbol{x} \in \boldsymbol{C} \subseteq \mathbb{R}^n$。算法每次提交一个**查询点**（query point）$\boldsymbol{q} \in \mathbb{R}^n$，黑箱返回一个实数 y，称为**读数**（reading）。查询点不一定等于当前迭代点，算法常常故意偏离当前点一点，再比较读数。

这里出现两种性质不同的随机性，如图 14.1所示。第一种在算法内部：算法自己抽取偏离的方向，这是我们主动加入的。第二种在黑箱内部：同一个查询点运行两次，可能因为测量噪声或仿真种子不同而得到不同的读数，这是我们无法控制的。

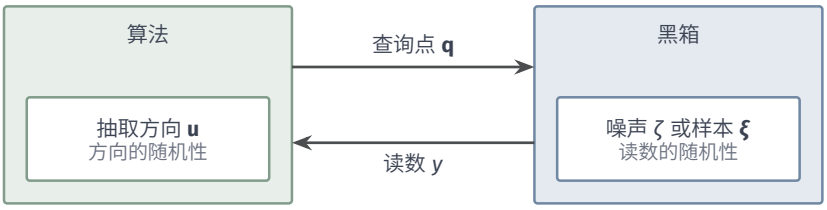


图 14.1 零阶优化的接口。算法提交查询点 $\boldsymbol{q}$，黑箱返回读数 y。方向 $\boldsymbol{u}$ 的随机性由算法产生，噪声 ζ 或样本 $\boldsymbol{\xi}$ 的随机性来自黑箱，二者相互独立地起作用，分析时分别记录。

14.1.1 精确函数值与含噪读数

按黑箱内部的情况，读数分成三种模型。图 14.2画出了它们在一条一元曲线上的样子。

三种读数模型 第一种是精确函数值，同一点读多少次都是同一个数：

$$y = f(\boldsymbol{q}). \tag{14.2}$$

第二种是带**加性噪声**（additive noise）的读数，真实值上叠加一个随机误差 ζ：

$$y = f(\boldsymbol{q}) + \zeta. \tag{14.3}$$

第三种是期望目标的样本函数值。目标本身定义成随机函数的平均，一次读数对应一个随机场景 $\boldsymbol{\xi}$：

$$f(\boldsymbol{x}) = \mathbb{E}_{\boldsymbol{\xi}}\big[F(\boldsymbol{x};\boldsymbol{\xi})\big], \qquad y = F(\boldsymbol{q};\boldsymbol{\xi}). \tag{14.4}$$

后两种的差别在于噪声是否依赖位置。贯穿例上取样本函数 $F(\boldsymbol{x};\boldsymbol{\xi}) = f(\boldsymbol{x}) + \boldsymbol{\xi}^{\top}\boldsymbol{x}$，$\boldsymbol{\xi}$ 均值为零。场景 $\boldsymbol{\xi} = (0.2, -0.1)$ 在起点给出

$$F(\boldsymbol{x}^{(0)};\boldsymbol{\xi}) = 45 + 0.2 \cdot 9 - 0.1 \cdot 1 = 46.7.$$

这里偏差 1.7 随 $\boldsymbol{x}$ 线性变化。固定一个场景，$F(\cdot;\boldsymbol{\xi})$ 是一条完整的曲线，如图 14.2(c)；而加性噪声模型里每次读数的误差是孤立的一个数，没有“这条曲线”可言。

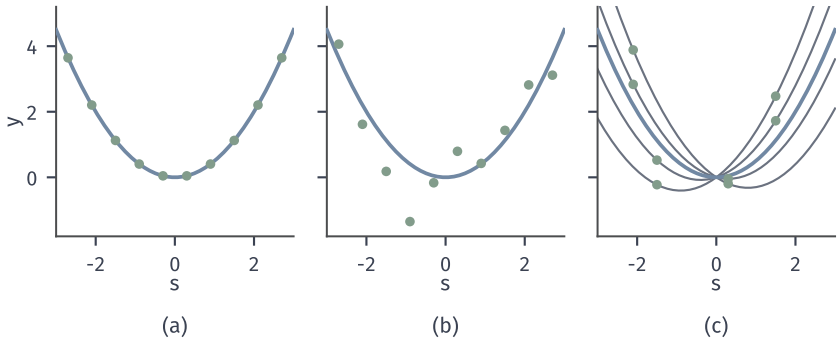


图 14.2　同一个目标 $s^2/2$（蓝线）的三种读数，绿点是读数。(a) 精确读数落在曲线上。(b) 加性噪声读数在曲线上下散开，标准差 0.6。(c) 样本函数 $s^2/2+\xi s$，取四个场景 ξ（灰线），绿点是同一场景曲线上的读数，蓝线是它们的期望。

无偏须对给定的历史和查询点成立　什么叫“读数没有系统偏差”？直观要求是平均起来等于真值。但这个平均必须在“算法已经知道的一切”都固定时计算，否则算法可能恰好挑中噪声偏低的位置。记 $\mathcal{H}$ 为提交本次查询之前算法产生的全部方向和读数。

> **定义 14.1　条件无偏读数**　读数 y 在查询点 $\boldsymbol{q}$ 处称为条件无偏（conditionally unbiased）的，如果
>
> $$\mathbb{E}\big[y \mid \mathcal{H}, \boldsymbol{q}\big] = f(\boldsymbol{q}). \tag{14.5}$$
>
> 其方差有界是指：给定 $\mathcal{H}$ 和 $\boldsymbol{q}$ 时，y 的条件方差不超过某个常数 $\sigma^2 < \infty$。

条件期望可以理解为：把算法手里的信息看作已知常数，只对尚未发生的随机性求平均。严格定义可参考卷七第 4 章“条件期望与条件分布”，本章只用这一层含义和逐层取期望的规则。

边际无偏是不够的。设两个候选的真实值都是 0，噪声等可能取 ± 1，每个候选的噪声一旦生成就不再变化。先各读一次，然后挑读数较低的候选再读一次。第一次读数的边际均值是 0，第二次读数却满足：

$$\mathbb{P}(\text{第二次读数} = -1) = \frac{3}{4}, \qquad \mathbb{P}(\text{第二次读数} = +1) = \frac{1}{4}.$$

14.1 函数值反馈
14.1.1 精确函数值与含噪读数
14.1.2 单点查询与成对查询
14.2 有限差分
14.3 随机平滑与梯度估计
14.4 零阶随机梯度方法
14.5 误差与查询成本
14.6 本章小结

第二次读数的均值是 $-\frac{1}{2}$，而被选中候选的真值是 0。噪声与“查询哪里”发生了关联，式 (14.5)不成立。这说明重复使用同一份噪声时，查询点不能依赖这份噪声生成的读数。

目标确定时也可以用随机方向 “随机优化”容易让人以为目标必须是随机的，其实不然。贯穿例 (14.1)若采用模型 (14.2)，黑箱完全确定。算法仍可以抽方向 $\boldsymbol{u} = (0.6, 0.8)$，查询 $\boldsymbol{x}^{(0)} \pm 0.5\boldsymbol{u}$，得到

$$f(9.3, 1.4) = 52.065, \qquad f(8.7, 0.6) = 39.465.$$

重读多少次这两个数都不变，唯一的随机性是方向。反过来，若固定方向沿坐标轴逐个差分而读数带噪声，随机性就全部来自黑箱。两种随机性可以单独出现，也可以同时出现，分析时分开记录。

14.1.2 单点查询与成对查询

读数的模型说的是一次读数的性质，还需要规定多次读数之间的关系。这里有两个相互独立的问题。

一轮能读几个位置 有些系统每次只能在一组参数下运行，下一轮参数已经变了，同一状态无法读第二个位置。这称为**单点查询**（single-point query）。另一些系统允许在同一轮提交两个位置，比如对称地偏离当前点，这称为**成对查询**（paired query）。前者更受限，后者能够比较两个读数，这是一项实质性的额外能力，不是实现细节。

两个位置能否共用一次仿真 成对查询时还要问：两次读数用的是不是同一个随机场景？比如仿真器允许固定随机种子，那么可以读

$$y_+ = F(\boldsymbol{q}_+; \boldsymbol{\xi}), \qquad y_- = F(\boldsymbol{q}_-; \boldsymbol{\xi}), \tag{14.6}$$

也就是沿同一条样本曲线读两点。这称为**共享样本**（shared sample），又叫共同随机数。如果种子无法控制，两个读数各带独立的噪声：

$$y_+ = f(\boldsymbol{q}_+) + \zeta_+, \qquad y_- = f(\boldsymbol{q}_-) + \zeta_-. \tag{14.7}$$

为什么不能混为一谈 两个模型的读数单独看可能分布完全相同，算差却完全不同。图 14.3取 $f(s) = s^2/2$，在 $s = 1$ 两侧相距 0.4 读两点，真实导数是 1。左边噪声独立，分别取 $+0.3$ 和 -0.3，差商是

$$\frac{y_+ - y_-}{2 \cdot 0.4} = \frac{(0.98 + 0.3) - (0.18 - 0.3)}{0.8} = 1.75.$$

右边两点共享噪声 +0.3，差商里这个数被减掉，得到准确的 1。相同大小的噪声，一边造成 75% 的误差，一边没有影响。

14.1 函数值反馈
14.2 有限差分
14.2.1 坐标差分
14.2.2 随机方向差分
14.2.3 同时扰动随机逼近
14.3 随机平滑与梯度估计
14.4 零阶随机梯度方法
14.5 误差与查询成本
14.6 本章小结

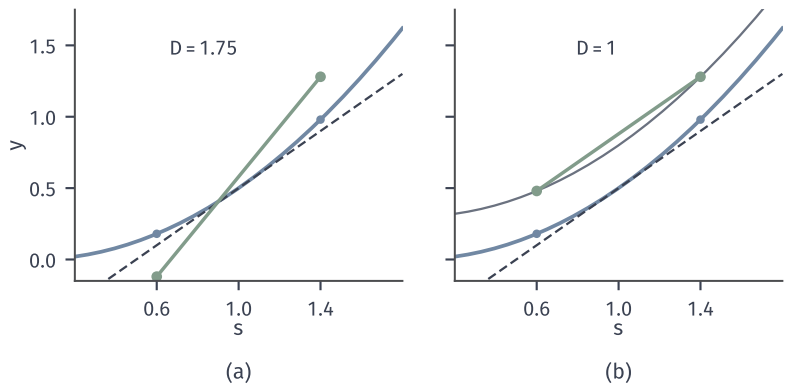


图 14.3 成对读数的两种接口，蓝线为 $f(s)=s^2/2$，虚线是 $s=1$ 处的切线，绿色线段连接两次读数，蓝点是真实函数值。(a) 两点噪声独立，分别为 +0.3 和 −0.3，线段斜率 1.75，偏离切线。(b) 两点共享噪声 +0.3，读数都落在灰色曲线上，斜率恰为 1。

所以误差界必须与实际接口匹配。文献和本章后面给出的速率都带着接口条件，表 14.1先列出本章要用到的四种情形，第 14.3.5节再推导对应的方差。

接口	一轮读数	两点之差的噪声
精确函数值	任意	无
单点，含噪	1	不适用
成对，独立噪声	2	方差 $2\sigma^2$，不随距离变小
成对，共享样本	2	取决于样本函数的波动

表 14.1 本章区分的查询接口。“独立噪声”指式 (14.7)，噪声方差为 σ^2；“共享样本”指式 (14.6)。

14.2 有限差分

只凭几个函数值，怎样得到梯度的近似？思路来自一元微积分：导数是割线斜率的极限，步子小一点，割线斜率就接近导数。

从一元差商开始 设 $\varphi(s)$ 是一元函数，$h>0$ 是**扰动尺度**（perturbation scale）。两种常用的**差商**（difference quotient）是**前向差分**（forward difference）和**中心差分**（central difference）：

$$\frac{\varphi(s+h)-\varphi(s)}{h},\qquad \frac{\varphi(s+h)-\varphi(s-h)}{2h}. \tag{14.8}$$

图 14.4用 $\varphi(s)=s^2/2+s^3/6$，$s_0=1$，$h=0.8$ 画出两条割线和切线。切线斜率是 $\varphi'(1)=1.5$。

由 $\varphi(1)=2/3$、$\varphi(1.8)=2.592$ 和 $\varphi(0.2)\approx 0.0213$，两种差商是

$$\frac{2.592-0.6667}{0.8}\approx 2.407,\qquad \frac{2.592-0.0213}{1.6}\approx 1.607.$$

前向差商偏离 0.907，中心差商只偏离 0.107。原因是 Taylor 展开的二次项：前向割线把弯曲全部算进了斜率，中心割线的两侧弯曲互相抵消。

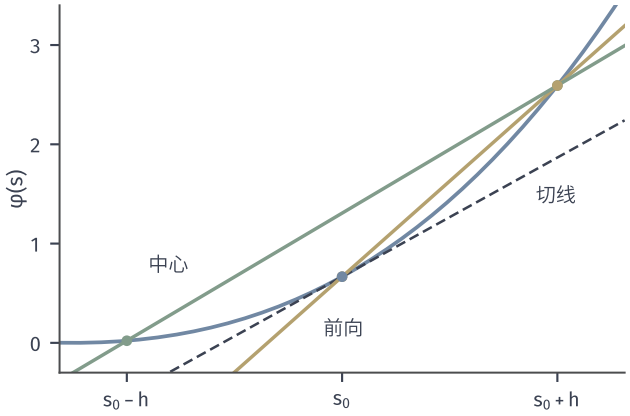


图 14.4　$\varphi(s)=s^2/2+s^3/6$（蓝线）在 $s_0=1$ 处的两种差商，$h=0.8$。虚线是切线，斜率 1.5；黄线是前向割线，斜率约 2.407；绿线是中心割线，斜率约 1.607，方向最接近切线。

多元函数：沿一个方向看　差商搬到多元函数上，只要限制在一条直线上。令 $\varphi(s)=f(\boldsymbol{x}+s\boldsymbol{u})$，由链式法则 $\varphi'(0)=\langle\nabla f(\boldsymbol{x}),\boldsymbol{u}\rangle$，这是方向导数。于是沿 $\boldsymbol{u}$ 的中心差商近似 $\langle\nabla f(\boldsymbol{x}),\boldsymbol{u}\rangle$。一次差商只告诉我们梯度在一个方向上的投影，要拼出整个梯度，需要多个方向，或者后面将看到的随机化。

下面的引理量化差商的**截断误差**（truncation error），它只涉及函数本身，不涉及噪声。第 5章的下降引理给出：∇f 是 L-Lipschitz 时，对任意 $\boldsymbol{x},\boldsymbol{v}$，

$$\left|f(\boldsymbol{x}+\boldsymbol{v})-f(\boldsymbol{x})-\langle\nabla f(\boldsymbol{x}),\boldsymbol{v}\rangle\right|\le\frac{L}{2}\|\boldsymbol{v}\|_2^2.$$

引理 14.2　差商的余项　设 ∇f 是 L-Lipschitz 的。对任意 $\boldsymbol{x},\boldsymbol{v}$，

$$\left|f(\boldsymbol{x}+\boldsymbol{v})-f(\boldsymbol{x}-\boldsymbol{v})-2\langle\nabla f(\boldsymbol{x}),\boldsymbol{v}\rangle\right|\le L\|\boldsymbol{v}\|_2^2. \tag{14.9}$$

若 f 还二阶连续可微，且 $\nabla^2 f$ 按谱范数是 M-Lipschitz 的，则

$$\left|f(\boldsymbol{x}+\boldsymbol{v})-f(\boldsymbol{x}-\boldsymbol{v})-2\langle\nabla f(\boldsymbol{x}),\boldsymbol{v}\rangle\right|\le\frac{M}{3}\|\boldsymbol{v}\|_2^3. \tag{14.10}$$

14.1 函数值反馈
14.2 有限差分
14.2.1 坐标差分
14.2.2 随机方向差分
14.2.3 同时扰动随机逼近
14.3 随机平滑与梯度估计
14.4 零阶随机梯度方法
14.5 误差与查询成本
14.6 本章小结

证明 把上面的不等式分别用于 $\boldsymbol{v}$ 和 $-\boldsymbol{v}$，两式相减，由三角不等式得式 (14.9)。

对第二个结论，记 $\boldsymbol{H} = \nabla^2 f(\boldsymbol{x})$。积分形式的 Taylor 公式给出

$$f(\boldsymbol{x}+\boldsymbol{v}) - f(\boldsymbol{x}) - \langle \nabla f(\boldsymbol{x}), \boldsymbol{v}\rangle - \frac{1}{2}\boldsymbol{v}^{\top}\boldsymbol{H}\boldsymbol{v} = \int_0^1 (1-s)\,\boldsymbol{v}^{\top}\big(\nabla^2 f(\boldsymbol{x}+s\boldsymbol{v}) - \boldsymbol{H}\big)\boldsymbol{v}\,\mathrm{d}s.$$

右端的绝对值不超过

$$\int_0^1 (1-s)\,M s\,\|\boldsymbol{v}\|_2^3\,\mathrm{d}s = \frac{M}{6}\|\boldsymbol{v}\|_2^3.$$

对 $\boldsymbol{v}$ 和 $-\boldsymbol{v}$ 各写一次再相减，二次项 $\frac{1}{2}\boldsymbol{v}^{\top}\boldsymbol{H}\boldsymbol{v}$ 恰好相消，余项相加得 $\frac{M}{3}\|\boldsymbol{v}\|_2^3$。 ■

三笔账 每种差分都要记三笔账。第一笔是截断误差，随 h 变小而变小。第二笔是读数噪声造成的误差：独立噪声方差 σ^2 时，前向差商的噪声是 $(\zeta_1-\zeta_0)/h$，中心差商的噪声是 $(\zeta_+-\zeta_-)/(2h)$，方差分别为

$$\frac{2\sigma^2}{h^2}, \qquad \frac{\sigma^2}{2h^2}, \tag{14.11}$$

都随 h 变小而变大。第三笔是查询次数。这三笔账彼此独立，下面逐个方法记录，第 14.5.1节再做取舍。

14.2.1 坐标差分

最直接的做法是沿 n 个坐标方向逐个差分，用 n 个方向导数拼成梯度。记 $\boldsymbol{e}_i$ 为第 i 个标准基向量，两种**坐标差分**（coordinate difference）的第 i 个分量是

$$\hat{g}_i^{\mathrm{F}} = \frac{f(\boldsymbol{x}+h\boldsymbol{e}_i) - f(\boldsymbol{x})}{h}, \qquad \hat{g}_i^{\mathrm{C}} = \frac{f(\boldsymbol{x}+h\boldsymbol{e}_i) - f(\boldsymbol{x}-h\boldsymbol{e}_i)}{2h}. \tag{14.12}$$

查询次数 前向差分的 n 个分量可以共用中心读数 $f(\boldsymbol{x})$，所以一共 $n+1$ 次查询。中心差分每个坐标读两点，共 $2n$ 次，中心点本身不读。图 14.5(a)(b) 画出了这两种查询模式。

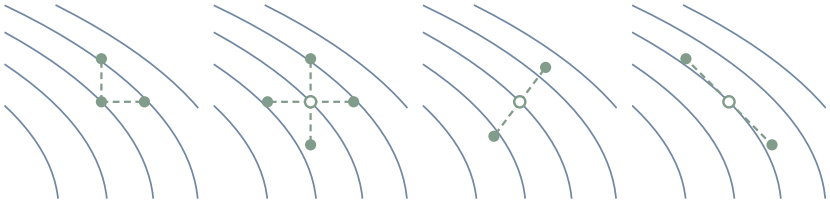


图 14.5　贯穿例在 $(9,1)$ 附近的查询点，蓝线是等高线，为便于观察取 $h=0.4$。实心点要读函数值，空心点是当前点、不读。(a) 前向坐标差分，3 次。(b) 中心坐标差分，4 次。(c) 沿 $\boldsymbol{u}=(0.6,0.8)$ 的随机方向差分，2 次。(d) 第 14.2.3节的同时扰动，$\boldsymbol{\Delta}=(1,-1)$，2 次，位移长度是 $h\sqrt{2}$。

手算比较　在贯穿例的起点取 $h=0.1$。为算前向差商，读三个函数值：

$$f(9,1)=45,\qquad f(9.1,1)=45.905,\qquad f(9,1.1)=45.945.$$

代入式 (14.12)，前向差分给出

$$\hat{\boldsymbol{g}}^{\mathrm{F}}=(9.05,\ 9.45).$$

真实梯度是 $(9,9)$，误差 $(0.05,\ 0.45)$，恰好等于 $\frac{h}{2}H_{ii}$：沿 x_2 方向弯曲是 x_1 方向的 9 倍，误差也是 9 倍。

再读 $f(8.9,1)=44.105$ 和 $f(9,0.9)=44.145$，中心差分给出

$$\hat{\boldsymbol{g}}^{\mathrm{C}}=\left(\frac{45.905-44.105}{0.2},\ \frac{45.945-44.145}{0.2}\right)=(9,\ 9).$$

对二次函数，中心差分没有截断误差，因为三阶以上的导数都是零。多付一次查询，换来了精确值。

截断误差的一般结论　上面的现象对一般函数也成立，只是阶数要由相应的导数条件来保证。

定理 14.3　坐标差分的截断误差　设读数精确。若 ∇f 是 L-Lipschitz 的，则

$$\|\hat{\boldsymbol{g}}^{\mathrm{F}}-\nabla f(\boldsymbol{x})\|_2\le\frac{\sqrt{n}\,Lh}{2}. \tag{14.13}$$

若 f 还二阶连续可微且 $\nabla^2 f$ 是 M-Lipschitz 的，则

$$\|\hat{\boldsymbol{g}}^{\mathrm{C}}-\nabla f(\boldsymbol{x})\|_2\le\frac{\sqrt{n}\,Mh^2}{6}. \tag{14.14}$$

14.1 函数值反馈
14.2 有限差分
14.2.1 坐标差分
14.2.2 随机方向差分
14.2.3 同时扰动随机逼近
14.3 随机平滑与梯度估计
14.4 零阶随机梯度方法
14.5 误差与查询成本
14.6 本章小结

证明 对前向差分，把下降引理用于 $\boldsymbol{v} = h\boldsymbol{e}_i$，再除以 h，得

$$|\hat{g}_i^{\mathrm{F}} - \partial_i f(\boldsymbol{x})| \le \frac{Lh}{2}.$$

对中心差分，把式 (14.10)用于 $\boldsymbol{v} = h\boldsymbol{e}_i$，再除以 $2h$，得

$$|\hat{g}_i^{\mathrm{C}} - \partial_i f(\boldsymbol{x})| \le \frac{Mh^2}{6}.$$

n 个分量各不超过同一个上界，向量的欧氏范数不超过该上界乘以 $\sqrt{n}$。 ■

定理的条件各有作用。前向差分只用到梯度的 Lipschitz 性，误差是一阶的。中心差分要快一阶，需要三阶信息受控，也就是 Hessian 的 Lipschitz 性；只有 L 时，由式 (14.9)只能得到每个分量 $Lh/2$，与前向差分同阶。

图 14.6在 $\varphi(s) = s^2/2 + s^3/6$ 上验证这两个阶数。双对数坐标下，前向误差的斜率是 1，中心误差的斜率是 2，h 每缩小 10 倍，中心差分的误差缩小 100 倍。

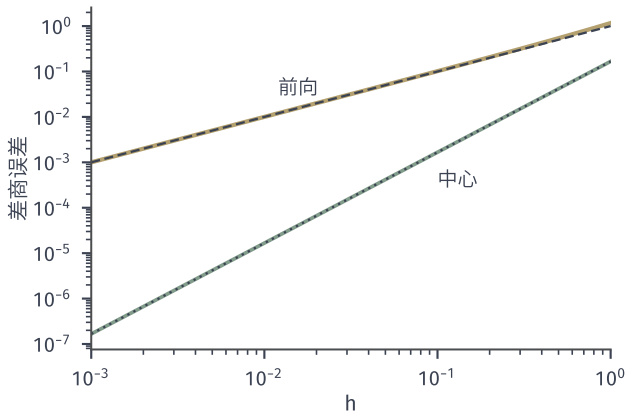


图 14.6 精确读数下差商误差随 h 的变化，$\varphi(s) = s^2/2 + s^3/6$，$s_0 = 1$，真实导数 1.5。黄线为前向差分，绿线为中心差分；虚线是 h，点线是 $h^2/6$，分别对应理论的斜率 1 和 2。

14.2.2 随机方向差分

坐标差分每算一次梯度要 n 轮查询，维数大时一步也走不起。一个自然的想法是：每轮只沿一个方向差分，方向随机抽，多轮平均下来也许能覆盖各个方向。

从方向导数恢复向量 一次差商是一个标量，要把它变成向量，乘上方向本身。设 $\boldsymbol{u}$ 在单位球面 $\boldsymbol{S}$（$\mathbb{R}^n$ 中全体长度为 1 的向量）上均匀分布。记

$\boldsymbol{g} = \nabla f(\boldsymbol{x})$，考察 $\langle \boldsymbol{g}, \boldsymbol{u}\rangle \boldsymbol{u}$ 的均值。由对称性，$\mathbb{E}[u_i u_j] = 0$（$i \neq j$），且 n 个 $\mathbb{E}[u_i^2]$ 相等，和为 1，所以

$$\mathbb{E}[\boldsymbol{u}\boldsymbol{u}^\top] = \frac{1}{n}\boldsymbol{I}.$$

于是

$$\mathbb{E}\big[\langle \boldsymbol{g}, \boldsymbol{u}\rangle \boldsymbol{u}\big] = \mathbb{E}[\boldsymbol{u}\boldsymbol{u}^\top]\boldsymbol{g} = \frac{1}{n}\boldsymbol{g}.$$

乘以 n 就得到 $\boldsymbol{g}$ 的无偏量。把方向导数换成中心差商，定义**随机方向差分**（random-direction difference）：

$$D_h(\boldsymbol{u}) = \frac{f(\boldsymbol{x} + h\boldsymbol{u}) - f(\boldsymbol{x} - h\boldsymbol{u})}{2h}, \qquad \hat{\boldsymbol{g}} = n\, D_h(\boldsymbol{u})\, \boldsymbol{u}. \tag{14.15}$$

一般地，若方向分布满足 $\mathbb{E}[\boldsymbol{u}\boldsymbol{u}^\top] = c\,\boldsymbol{I}$，归一化因子就是 $1/c$。因子 n 来自单位球面的二阶矩，不是万能常数。

一条方向只有一条方向的信息　在起点，贯穿例是二次函数，中心差商精确等于方向导数，$\hat{\boldsymbol{g}} = 2\langle \boldsymbol{g}, \boldsymbol{u}\rangle \boldsymbol{u}$。取几个方向，结果如下：

$$\boldsymbol{u} = (1, 0):\ \hat{\boldsymbol{g}} = (18, 0), \qquad \boldsymbol{u} = (0, 1):\ \hat{\boldsymbol{g}} = (0, 18).$$

第三、第四个方向是 $(1, 1)/\sqrt{2}$ 和 $(1, -1)/\sqrt{2}$，得到

$$\hat{\boldsymbol{g}} = (18, 18), \qquad \hat{\boldsymbol{g}} = (0, 0).$$

四个估计的平均是 $(9, 9)$，但没有一个单独接近 $(9, 9)$。方向 $(1, -1)/\sqrt{2}$ 与梯度垂直，一条差商得到零，什么也看不出来。

图 14.7(a) 说明所有估计的分布：$n = 2$ 时，$2\langle \boldsymbol{g}, \boldsymbol{u}\rangle \boldsymbol{u}$ 走遍一个以 $\boldsymbol{g}$ 为圆心、过原点的圆。圆心就是均值，半径就是误差的大小。单个估计总是偏离 $\|\boldsymbol{g}\|_2$，只有平均才接近 $\boldsymbol{g}$。

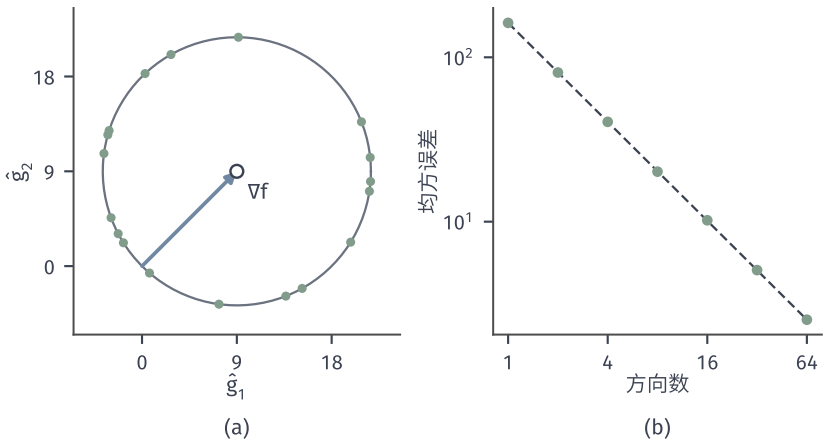


图 14.7 贯穿例起点处 $\boldsymbol{g} = (9, 9)$ 的随机方向估计。(a) 绿点是 18 个随机方向给出的 $2\langle \boldsymbol{g}, \boldsymbol{u}\rangle \boldsymbol{u}$，全部落在以 $\boldsymbol{g}$（空心圆）为圆心、半径 $\|\boldsymbol{g}\|_2$ 的灰圆上，蓝色箭头是真实梯度。(b)m 个独立方向平均后的均方误差，绿点是 Monte Carlo 结果，虚线是 $162/m$。

偏差与二阶矩 下面的定理把偏差和波动分开。

定理 14.4 随机方向差分 设读数精确，$\boldsymbol{u}$ 在 $\boldsymbol{S}$ 上均匀分布，$\hat{\boldsymbol{g}}$ 由式 (14.15)定义。若 f 是二次函数，则

$$\mathbb{E}[\hat{\boldsymbol{g}}] = \boldsymbol{g}, \qquad \mathbb{E}\|\hat{\boldsymbol{g}} - \boldsymbol{g}\|_2^2 = (n-1)\|\boldsymbol{g}\|_2^2. \tag{14.16}$$

若 f 二阶连续可微且 $\nabla^2 f$ 是 M-Lipschitz 的，则偏差满足

$$\left\|\mathbb{E}[\hat{\boldsymbol{g}}] - \boldsymbol{g}\right\|_2 \le \frac{nMh^2}{6}. \tag{14.17}$$

证明 二次函数的中心差商没有余项，$\hat{\boldsymbol{g}} = n\langle \boldsymbol{g}, \boldsymbol{u}\rangle \boldsymbol{u}$，由 $\mathbb{E}[\boldsymbol{u}\boldsymbol{u}^{\top}] = \boldsymbol{I}/n$ 得 $\mathbb{E}[\hat{\boldsymbol{g}}] = \boldsymbol{g}$。

二阶矩用 $\|\boldsymbol{u}\|_2 = 1$ 计算：

$$\mathbb{E}\|\hat{\boldsymbol{g}}\|_2^2 = n^2 \mathbb{E}\langle \boldsymbol{g}, \boldsymbol{u}\rangle^2 = n^2 \cdot \frac{\|\boldsymbol{g}\|_2^2}{n} = n\|\boldsymbol{g}\|_2^2.$$

减去均值的平方 $\|\boldsymbol{g}\|_2^2$，得到方差。

一般情形写 $D_h(\boldsymbol{u}) = \langle \boldsymbol{g}, \boldsymbol{u}\rangle + r$。把式 (14.10)用于 $\boldsymbol{v} = h\boldsymbol{u}$ 并除以 $2h$，得 $|r| \le Mh^2/6$。于是

$$\left\|\mathbb{E}[\hat{\boldsymbol{g}}] - \boldsymbol{g}\right\|_2 = n\left\|\mathbb{E}[r\boldsymbol{u}]\right\|_2 \le n\,\mathbb{E}|r| \le \frac{nMh^2}{6}.$$

14.1 函数值反馈
14.2 有限差分
14.2.1 坐标差分
14.2.2 随机方向差分
14.2.3 同时扰动随机逼近
14.3 随机平滑与梯度估计
14.4 零阶随机梯度方法
14.5 误差与查询成本
14.6 本章小结

■

式 (14.16)的 $n-1$ 就是维数的代价：一条方向只探测了 n 维中的一维，其余 $n-1$ 维的信息要靠多轮平均。图 14.7(b) 验证了 m 个独立方向平均后，均方误差按 $(n-1)\|\boldsymbol{g}\|_2^2/m$ 下降。

有限扰动下一般有偏 二次函数上的无偏是特例。一旦有三阶项，中心差商不再等于方向导数，由它乘 $\boldsymbol{u}$ 形成的向量，均值一般不等于原梯度。取 $n=2$，$f(\boldsymbol{x})=x_1^3$，在 $x_1=0$ 处真实梯度为零。差商和估计为

$$D_h(\boldsymbol{u})=h^2u_1^3,\qquad \hat{\boldsymbol{g}}=2h^2u_1^3\,\boldsymbol{u}.$$

记 $\boldsymbol{u}=(\cos\theta,\sin\theta)$。由 $\mathbb{E}[\cos^4\theta]=\tfrac{3}{8}$ 和 $\mathbb{E}[\cos^3\theta\sin\theta]=0$，

$$\mathbb{E}[\hat{\boldsymbol{g}}]=\left(\tfrac{3}{4}h^2,\,0\right)\neq\mathbf{0}.$$

这里 $M=6$，定理的界是 $2h^2$，实际偏差 $\tfrac{3}{4}h^2$ 在界内。偏差确实存在，而且随 h 平方缩小。

14.2.3 同时扰动随机逼近

随机方向差分要从球面上抽方向，并且需要因子 n。Spall 提出的**同时扰动随机逼近**（simultaneous perturbation stochastic approximation，SPSA）用更简单的方式达到类似的效果：让所有坐标同时动一下，每个坐标只取正负两个方向。

主要思想 抽取向量 $\boldsymbol{\Delta}\in\{-1,+1\}^n$，各分量独立，等可能取 ±1。查询两点 $\boldsymbol{x}\pm h\boldsymbol{\Delta}$，算一个函数差，再把同一个差除以各分量的扰动：

$$D=\frac{y_+-y_-}{2h},\qquad \hat{g}_i=\frac{D}{\Delta_i},\quad i=1,\dots,n. \tag{14.18}$$

只读了两次，却得到了 n 个分量。为什么这样能行？若 f 是二次函数，$D=\langle\boldsymbol{g},\boldsymbol{\Delta}\rangle$，于是

$$\hat{g}_i=g_i+\sum_{j\neq i}g_j\frac{\Delta_j}{\Delta_i}.$$

第一项是想要的。后面每一项都是其他坐标的“串扰”。因为 Δ_j 与 Δ_i 独立，且 $\mathbb{E}[\Delta_j]=0$，串扰的均值是零，平均之后消失。

除法要求 $\mathbb{E}[1/|\Delta_i|]$ 有限，这解释了分布的选择。正态或区间上的均匀扰动在 0 附近有正的密度，$1/|\Delta_i|$ 的期望发散，不能用于这个公式。±1 时 $1/\Delta_i=\Delta_i$，估计也可以写成 $\hat{\boldsymbol{g}}=D\,\boldsymbol{\Delta}$。

手算四种情形 贯穿例起点，$h = 0.1$，$n = 2$，$\boldsymbol{\Delta}$ 有四种等可能取值。取 $\boldsymbol{\Delta} = (1, 1)$，读数和差商是

$$y_+ = f(9.1, 1.1) = 46.85, \qquad y_- = f(8.9, 0.9) = 43.25, \qquad D = 18.$$

取 $\boldsymbol{\Delta} = (1, -1)$，两次读数相等，差商为零：

$$y_+ = f(9.1, 0.9) = 45.05, \qquad y_- = f(8.9, 1.1) = 45.05, \qquad D = 0.$$

$-\boldsymbol{\Delta}$ 与 $\boldsymbol{\Delta}$ 的结果相同。四种情形的估计分别是 $(18, 18)$、$(0, 0)$、$(0, 0)$、$(18, 18)$，平均恰为 $(9, 9)$，如图 14.8(b)。

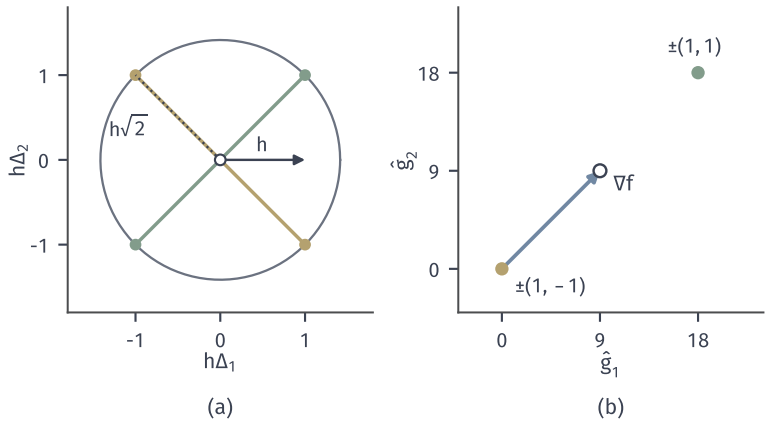


图 14.8 $n = 2$ 时的同时扰动。(a) 四个扰动 $h\boldsymbol{\Delta}$（$h = 1$）位于正方形顶点，一对相反的点共用一次差分，绿、黄各一对；每个坐标只动 h，位移长度却是 $h\sqrt{2}$，四点都在半径 $h\sqrt{2}$ 的圆上。(b) 贯穿例起点的估计，绿点是 $\boldsymbol{\Delta} = \pm(1, 1)$ 的结果，黄点是 $\boldsymbol{\Delta} = \pm(1, -1)$ 的结果，它们的平均是真实梯度（空心圆）。

偏差与噪声 SPSA 在原梯度上的偏差由差商余项决定，与随机方向差分的结论形式一样，只是这里的位移长度不再是 h。

定理 14.5 SPSA 的偏差 设 f 二阶连续可微，$\nabla^2 f$ 是 M-Lipschitz 的，$\boldsymbol{\Delta}$ 的分量独立且等可能取 ± 1，读数为 $y_\pm = f(\boldsymbol{x} \pm h\boldsymbol{\Delta}) + \zeta_\pm$，且给定 $\boldsymbol{x}, \boldsymbol{\Delta}$ 时 $\zeta_+ - \zeta_-$ 的条件均值为零。则对 $\hat{\boldsymbol{g}}$ 的每个分量，

$$\left| \mathbb{E}[\hat{g}_i \mid \boldsymbol{x}] - \partial_i f(\boldsymbol{x}) \right| \le \frac{M h^2 n^{3/2}}{6}. \tag{14.19}$$

证明 $\|h\boldsymbol{\Delta}\|_2 = h\sqrt{n}$。把差商写成主项、余项和噪声三部分：

$$D = \langle \boldsymbol{g}, \boldsymbol{\Delta} \rangle + r + \frac{\zeta_+ - \zeta_-}{2h}.$$

由式 (14.10)，余项满足

$$|r| \le \frac{1}{2h} \cdot \frac{M}{3} (h\sqrt{n})^3 = \frac{M h^2 n^{3/2}}{6}.$$

除以 Δ_i 后取条件期望。主项由串扰的零均值给出 g_i；噪声项先对给定的 $\boldsymbol{\Delta}$ 取期望，为零；余项的绝对值不变，因为 $|\Delta_i| = 1$。 ■

对二次函数 $r = 0$，SPSA 精确无偏。一般函数上 h 有限时仍有偏差，只有 $h \to 0$ 时偏差才消失，这一点与随机方向差分相同。定理只要求噪声差的条件均值为零，噪声本身不必独立。

坐标尺度与位移长度 比较 SPSA 和球面方向时容易犯一个错误：SPSA 的 h 是每个坐标的扰动，实际位移长度是 $h\sqrt{n}$。在 $n = 100$、$h = 0.1$ 时，查询点已偏离当前点 1 个单位。公平的比较要令位移长度相同，取 $h = \delta/\sqrt{n}$ 与球面半径 δ 对应。

这样比较之后两者的噪声完全一致。独立噪声下，SPSA 的 $\|\hat{\boldsymbol{g}}\|_2^2$ 中噪声贡献的均值是 $n\sigma^2/(2h^2)$，代入 $h = \delta/\sqrt{n}$ 得

$$\frac{n^2\sigma^2}{2\delta^2},$$

恰好等于球面方向的噪声贡献 $n^2 \cdot \sigma^2/(2\delta^2)$。二次函数上，SPSA 的二阶矩也与球面方向相同：

$$\mathbb{E}\|\hat{\boldsymbol{g}}\|_2^2 = n\,\mathbb{E}\langle \boldsymbol{g}, \boldsymbol{\Delta} \rangle^2 = n\|\boldsymbol{g}\|_2^2.$$

SPSA 的优势主要在实现简单，每个坐标扰动大小固定。

表 14.2汇总本节三种差分。

方法	查询	截断偏差	独立噪声的二阶矩
前向坐标	$n+1$	$\sqrt{n}Lh/2$	$2n\sigma^2/h^2$
中心坐标	$2n$	$\sqrt{n}Mh^2/6$	$n\sigma^2/(2h^2)$
随机方向	2	$nMh^2/6$	$n^2\sigma^2/(2h^2)$
SPSA	2	$n^2Mh^2/6$	$n\sigma^2/(2h^2)$

表 14.2 三种差分的成本与误差。偏差为欧氏范数的上界，SPSA 一行由式 (14.19) 乘 $\sqrt{n}$ 得到。独立噪声的二阶矩指 $\mathbb{E}\|$噪声造成的估计误差$\|_2^2$，SPSA 的 h 是坐标尺度，位移长度为 $h\sqrt{n}$。

14.3 随机平滑与梯度估计

14.1 函数值反馈
14.2 有限差分
14.3 随机平滑与梯度估计
14.3.1 平滑目标
14.3.2 单点估计
14.3.3 双点估计
14.3.4 高斯方向估计
14.3.5 成对读数的噪声
14.4 零阶随机梯度方法
14.5 误差与查询成本
14.6 本章小结

上一节的估计以原梯度为目标，有限的 h 总带来偏差。于是要问：能否换一个目标，让函数值给出的估计严格无偏？答案是把目标函数在一个小邻域上取平均。平均之后的函数有自己的梯度，而这个梯度恰好可以写成函数值的期望。

打个比方，用原目标比较两点的高低，好比踩着一块小石头判断地面坡度，容易被局部起伏误导；平滑目标则像站在一块平板上，平板的倾斜由它覆盖的整片地面决定。我们估计的是平板的倾斜，不是脚下那一点的坡度。比方的边界也要记住：平板的倾斜和地面的坡度是两个对象，它们的差别要到第 14.5.3节才算清。

14.3.1 平滑目标

定义 记 $\boldsymbol{B}$ 为 $\mathbb{R}^n$ 中的单位球，即全体长度不超过 1 的向量。下面给出两种平均方式，$\delta>0$ 是球的半径，$\tau>0$ 是高斯分布的尺度。

> **定义 14.6 球平滑与高斯平滑** 设 $\boldsymbol{v}$ 在 $\boldsymbol{B}$ 上均匀分布，$\boldsymbol{w}\sim\mathcal{N}(\mathbf{0},\boldsymbol{I})$。$f$ 的**球平滑**（ball smoothing）与**高斯平滑**（Gaussian smoothing）分别是
>
> $$f_\delta^{\mathrm{B}}(\boldsymbol{x})=\mathbb{E}_{\boldsymbol{v}}\big[f(\boldsymbol{x}+\delta\boldsymbol{v})\big],\qquad f_\tau^{\mathrm{G}}(\boldsymbol{x})=\mathbb{E}_{\boldsymbol{w}}\big[f(\boldsymbol{x}+\tau\boldsymbol{w})\big]. \tag{14.20}$$
>
> 前提是期望有定义。它们统称**平滑目标**（smoothed objective）。

定义成立需要什么 两种平均对 f 的要求不同。球平滑只看 $\boldsymbol{x}$ 周围半径 δ 的球，f 在这个球上局部可积就够了，比如局部连续。它对球外的 f 没有任何要求。

高斯平滑要看整个空间，于是必须控制 f 在无穷远的增长，局部的好性质帮不上忙。例如 $n=1$，$f(x)=e^{x^2}$ 处处光滑，但

$$\mathbb{E}\big[e^{(x+\tau w)^2}\big]<\infty \quad\Longleftrightarrow\quad 2\tau^2<1.$$

$\tau\ge 1/\sqrt{2}$ 时高斯平滑根本不存在。多项式增长或指数增长（$|f(\boldsymbol{z})|$ 不超过 $Ce^{a\|\boldsymbol{z}\|_2}$）都可以被高斯密度压住。

二次函数上的平滑 贯穿例上平滑的效果可以算出来。二次函数满足

$$f(\boldsymbol{x}+\boldsymbol{z})=f(\boldsymbol{x})+\langle\nabla f(\boldsymbol{x}),\boldsymbol{z}\rangle+\frac{1}{2}\boldsymbol{z}^{\top}\boldsymbol{H}\boldsymbol{z}.$$

取 $\boldsymbol{z}$ 为对称分布的扰动，一次项的期望为零。均匀球上 $\mathbb{E}[\boldsymbol{v}\boldsymbol{v}^{\top}] = \boldsymbol{I}/(n+2)$，所以

$$f_{\delta}^{\mathrm{B}}(\boldsymbol{x}) = f(\boldsymbol{x}) + \frac{\delta^2 \operatorname{tr}\boldsymbol{H}}{2(n+2)}, \qquad f_{\tau}^{\mathrm{G}}(\boldsymbol{x}) = f(\boldsymbol{x}) + \frac{\tau^2 \operatorname{tr}\boldsymbol{H}}{2}.$$

贯穿例 $\operatorname{tr}\boldsymbol{H} = 10$，$n = 2$，分别得到 $f + 1.25\delta^2$ 和 $f + 5\tau^2$。平滑只把目标抬高一个常数，梯度完全不变。所以在二次函数上，平滑目标的梯度就是原梯度，这也解释了上一节的中心差分为什么在二次函数上无偏。

绝对值函数：不可微时平滑仍可微　平滑真正的用处在不光滑的目标上。$f(x) = |x|$ 在 0 处没有导数。$n = 1$ 时单位球是区间 $[-1, 1]$，直接积分得到

$$f_{\delta}^{\mathrm{B}}(x) = \begin{cases} \dfrac{x^2 + \delta^2}{2\delta}, & |x| \le \delta, \\ |x|, & |x| > \delta. \end{cases} \tag{14.21}$$

它的导数在 $|x| \le \delta$ 上是 x/δ，在 $x = \pm\delta$ 处与外侧的 ± 1 衔接，因此连续可微。高斯平滑的结果用误差函数表示：

$$f_{\tau}^{\mathrm{G}}(x) = \tau\sqrt{\frac{2}{\pi}}\, e^{-x^2/(2\tau^2)} + x \operatorname{erf}\!\Big(\frac{x}{\sqrt{2}\tau}\Big).$$

图 14.9取 $\delta = 1$，$\tau = 1/\sqrt{3}$，这时两种扰动的方差相同。尖点被磨圆了，但代价也在图上：$x = 0$ 处，两条曲线的值分别是 $1/2$ 和约 0.46，原函数值是 0。

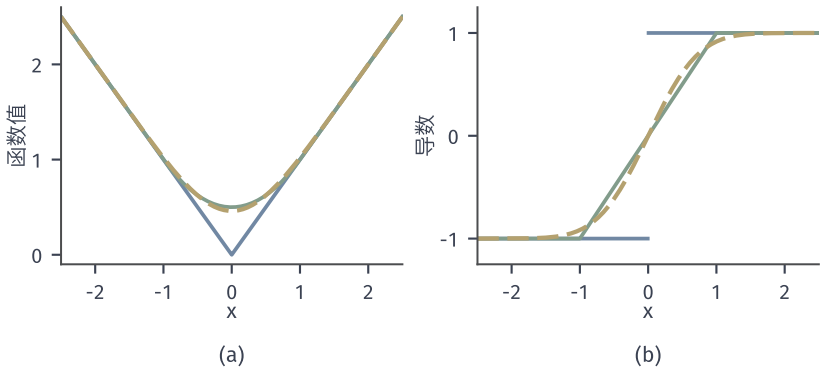


图 14.9　$f(x) = |x|$ 的平滑。蓝线是原函数，绿线是 $\delta = 1$ 的球平滑，黄色虚线是 $\tau = 1/\sqrt{3}$ 的高斯平滑。(a) 函数值，尖点被磨圆且抬高。(b) 导数，原函数在 0 处跳变，平滑后连续。

平滑误差　平滑目标与原目标差多少，由原目标的光滑程度决定。下面的引理后面会多次使用。

引理 14.7 平滑的基本性质 1. 若 ∇f 是 L-Lipschitz 的，则 f_δ^{B} 与 f_τ^{G} 的梯度也是 L-Lipschitz 的，并且

$$|f_\delta^{\mathrm{B}} - f| \le \frac{L\delta^2}{2}, \qquad \|\nabla f_\delta^{\mathrm{B}} - \nabla f\|_2 \le L\delta, \tag{14.22}$$

$$|f_\tau^{\mathrm{G}} - f| \le \frac{L\tau^2 n}{2}, \qquad \|\nabla f_\tau^{\mathrm{G}} - \nabla f\|_2 \le L\tau\sqrt{n}. \tag{14.23}$$

2. 若 f 是 G-Lipschitz 的，则

$$|f_\delta^{\mathrm{B}} - f| \le G\delta. \tag{14.24}$$

3. 若 f 是凸函数，则平滑目标也是凸函数，且 $f_\delta^{\mathrm{B}} \ge f$，$f_\tau^{\mathrm{G}} \ge f$。

证明 只写球平滑，高斯平滑把 $\delta\boldsymbol{v}$ 换成 $\tau\boldsymbol{w}$，并用 $\mathbb{E}\|\boldsymbol{w}\|_2^2 = n$ 与 $\mathbb{E}\|\boldsymbol{w}\|_2 \le \sqrt{n}$。

第一项。∇f 连续且至多线性增长，可在期望号下求导：

$$\nabla f_\delta^{\mathrm{B}}(\boldsymbol{x}) = \mathbb{E}\big[\nabla f(\boldsymbol{x} + \delta\boldsymbol{v})\big].$$

两点作差，由 ∇f 的 Lipschitz 性得到相同常数 L。由 $\mathbb{E}[\boldsymbol{v}] = \boldsymbol{0}$，

$$f_\delta^{\mathrm{B}}(\boldsymbol{x}) - f(\boldsymbol{x}) = \mathbb{E}\big[f(\boldsymbol{x} + \delta\boldsymbol{v}) - f(\boldsymbol{x}) - \delta\langle\nabla f(\boldsymbol{x}), \boldsymbol{v}\rangle\big].$$

下降引理给出右端绝对值不超过

$$\frac{L}{2}\delta^2\,\mathbb{E}\|\boldsymbol{v}\|_2^2 \le \frac{L\delta^2}{2}.$$

梯度差由 ∇f 的 Lipschitz 性取期望，不超过 $L\delta$。

第二项由下式取期望得到：

$$|f(\boldsymbol{x} + \delta\boldsymbol{v}) - f(\boldsymbol{x})| \le G\delta\|\boldsymbol{v}\|_2 \le G\delta.$$

第三项。对每个固定的 $\boldsymbol{v}$，$\boldsymbol{x} \mapsto f(\boldsymbol{x} + \delta\boldsymbol{v})$ 是凸函数，凸函数的平均是凸函数。再由 Jensen 不等式：凸函数在随机点上的平均不小于在平均点上的值，

$$f_\delta^{\mathrm{B}}(\boldsymbol{x}) = \mathbb{E}[f(\boldsymbol{x} + \delta\boldsymbol{v})] \ge f\big(\boldsymbol{x} + \delta\mathbb{E}[\boldsymbol{v}]\big) = f(\boldsymbol{x}).$$

■

14.1 函数值反馈
14.2 有限差分
14.3 随机平滑与梯度估计
14.3.1 平滑目标
14.3.2 单点估计
14.3.3 双点估计
14.3.4 高斯方向估计
14.3.5 成对读数的噪声
14.4 零阶随机梯度方法
14.5 误差与查询成本
14.6 本章小结

式 (14.23)比式 (14.22)多了维数因子。这不是高斯平滑更差，而是 τ 的含义不同：$\tau \boldsymbol{w}$ 的长度约为 $\tau\sqrt{n}$。令 $\tau = \delta/\sqrt{n}$ 时，两组界同阶。

14.3.2 单点估计

现在寻找用函数值表示平滑梯度的公式。出发点是一个几何观察,图 14.10画的是 $n = 2$ 的情形。

主要思想 把球心从 $\boldsymbol{x}$ 移动一点点到 $\boldsymbol{x} + \Delta\boldsymbol{x}$，球内积分的变化只发生在边界：右边新进入一片月牙，左边离开一片月牙，中间的部分原封不动。所以球平均的变化率完全由球面上的函数值决定，球内部的值只通过边界起作用。

把这个想法写成式子。月牙在法向 $\boldsymbol{u}$ 处的厚度是 $\langle \Delta\boldsymbol{x}, \boldsymbol{u}\rangle$，于是积分的一阶变化是球面积分 $\int f(\boldsymbol{x} + \delta\boldsymbol{u})\langle \Delta\boldsymbol{x}, \boldsymbol{u}\rangle \, \mathrm{d}S$。再除以球的体积。半径 δ 的球面积与球体积之比是 n/δ，这就是公式里因子的来历。

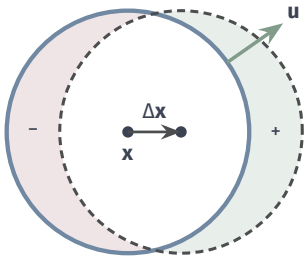


图 14.10 球平滑梯度的来历。蓝色实线是以 $\boldsymbol{x}$ 为心的圆，虚线是平移 $\Delta\boldsymbol{x}$ 后的圆。绿色月牙是新进入的区域，红色月牙是离开的区域，公共部分对积分的变化没有贡献。月牙在外法向 $\boldsymbol{u}$ 处的厚度约为 $\langle \Delta\boldsymbol{x}, \boldsymbol{u}\rangle$。

定理 14.8 球平滑的梯度恒等式 设 f 在开集 $\boldsymbol{U}$ 上连续，闭球 $\boldsymbol{x} + \delta\boldsymbol{B} \subset \boldsymbol{U}$，$\boldsymbol{u}$ 在单位球面 $\boldsymbol{S}$ 上均匀分布。则 f_δ^{B} 在 $\boldsymbol{x}$ 处可微，且

$$\nabla f_\delta^{\mathrm{B}}(\boldsymbol{x}) = \frac{n}{\delta}\, \mathbb{E}_{\boldsymbol{u}}\big[f(\boldsymbol{x} + \delta\boldsymbol{u})\, \boldsymbol{u}\big]. \tag{14.25}$$

证明 先设 f 连续可微。可在积分号下求导，得

$$\partial_i f_\delta^{\mathrm{B}}(\boldsymbol{x}) = \frac{1}{\mathrm{vol}(\delta\boldsymbol{B})} \int_{\delta\boldsymbol{B}} \partial_i f(\boldsymbol{x} + \boldsymbol{z})\, \mathrm{d}\boldsymbol{z}.$$

对向量场 $f(\boldsymbol{x} + \boldsymbol{z})\boldsymbol{e}_i$ 在球 $\delta\boldsymbol{B}$ 上用散度定理，外法向是 $\boldsymbol{z}/\delta$，于是

$$\partial_i f_\delta^{\mathrm{B}}(\boldsymbol{x}) = \frac{1}{\mathrm{vol}(\delta\boldsymbol{B})} \int_{\delta\boldsymbol{S}} f(\boldsymbol{x} + \boldsymbol{z}) \frac{z_i}{\delta}\, \mathrm{d}S(\boldsymbol{z}).$$

> 半径 δ 的球体积是 $c\,\delta^n$，对半径求导得球面积 $nc\,\delta^{n-1}$，两者之比为 n/δ。把球面积分写成均匀分布下的期望，$\boldsymbol{z}=\delta\boldsymbol{u}$，就得到式 (14.25)。
>
> 再设 f 只连续。取 $\boldsymbol{x}$ 的一个小邻域，使它的 δ 膨胀的闭包是 $\boldsymbol{U}$ 内的紧集，用光滑函数 f_k 在这个紧集上一致逼近 f。f_k 的平滑函数一致收敛到 f_δ^{B}，它们的梯度由恒等式给出，一致收敛到式 (14.25)右端，右端关于位置连续。函数列一致收敛且导数列一致收敛时，极限函数可微且导数等于导数的极限。 ■

定理要求 f 连续，这个条件不能省。球面在球内的体积为零，把 f 在球面上的值任意修改，f_δ^{B} 不变，式 (14.25)的右端却变了。恒等式右端要读取球面上的值，这些值必须与球内的值相联系，连续性保证了这一点。

估计器 恒等式的右端是期望，抽一个方向就得到它的无偏样本。这称为**单点估计**（one-point estimator）：

$$\hat{\boldsymbol{g}}^{(1)}=\frac{n}{\delta}\,y\,\boldsymbol{u},\qquad y=f(\boldsymbol{x}+\delta\boldsymbol{u}). \tag{14.26}$$

它每轮只需一次读数，单点接口也能用。读数含噪声时，只要给定历史、位置和方向时 ζ 的条件均值为零，噪声项 $\zeta\boldsymbol{u}$ 的均值就是零，估计的均值不变，仍是 $\nabla f_\delta^{\mathrm{B}}(\boldsymbol{x})$。注意查询点在球面上，但被估计的是球内平均的梯度，两个集合不要混淆。

常数偏移改变二阶矩 目标加一个常数 c，梯度不变，估计的均值也不变，因为 $\mathbb{E}[c\boldsymbol{u}]=\boldsymbol{0}$。可是估计本身变了。由 $\|\boldsymbol{u}\|_2=1$，

$$\mathbb{E}\|\hat{\boldsymbol{g}}^{(1)}\|_2^2=\frac{n^2}{\delta^2}\,\mathbb{E}\big[y^2\big], \tag{14.27}$$

读数绝对值越大，二阶矩越大，哪怕它的大小与优化毫无关系。

贯穿例起点 $f=45$，取 $\delta=0.1$，$n=2$，因子 $n/\delta=20$。沿 $\pm\boldsymbol{e}_1$ 方向的两个估计是

$$\boldsymbol{u}=\boldsymbol{e}_1:\ (918.1,\ 0),\qquad \boldsymbol{u}=-\boldsymbol{e}_1:\ (-882.1,\ 0).$$

沿 $\pm\boldsymbol{e}_2$ 方向是

$$\boldsymbol{u}=\boldsymbol{e}_2:\ (0,\ 918.9),\qquad \boldsymbol{u}=-\boldsymbol{e}_2:\ (0,\ -882.9).$$

四个向量的平均是 $(9,9)$，等于真实梯度，但每个向量的长度约为 900，比梯度长度 12.7 大七十倍。巨大的数相互抵消后才剩下需要的信号，如图 14.11(a)。

14.1 函数值反馈
14.2 有限差分
14.3 随机平滑与梯度估计
14.3.1 平滑目标
14.3.2 单点估计
14.3.3 双点估计
14.3.4 高斯方向估计
14.3.5 成对读数的噪声
14.4 零阶随机梯度方法
14.5 误差与查询成本
14.6 本章小结

如果事先知道 f 大约在 45 附近，把估计中的 y 换成 $y-45$，均值不变，散布却缩回 20 左右，如图 14.11(b)。可是这个常数算法事先并不知道，这就引出了下一小节的成对读数。

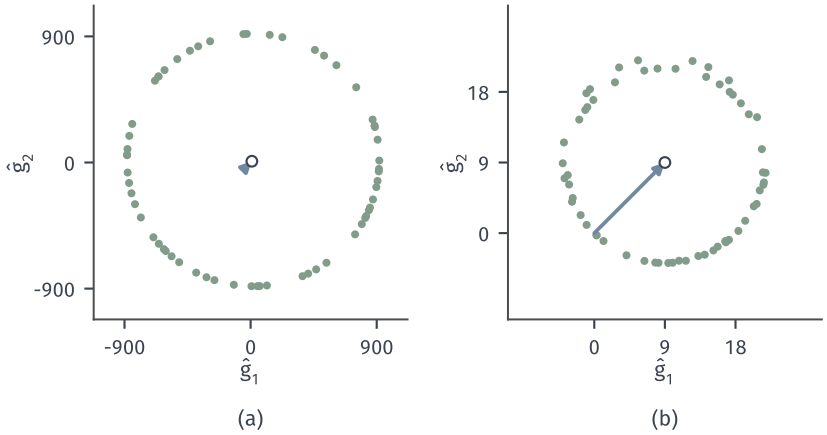


图 14.11 贯穿例起点的单点估计，$\delta = 0.1$，60 个随机方向。绿点是估计值，蓝色箭头是真实梯度 $(9,9)$，空心圆是它的终点。(a) 原读数的估计分布在半径约 900 的圆上，比梯度大两个量级。(b) 读数减去常数 45 后，同样的 60 个方向给出的估计缩到半径约 13 的圆上。两张图的坐标范围不同。

平滑目标的光滑常数 单点估计常用于 f 只是 G-Lipschitz 的情形。这时 f_δ^{B} 是否光滑？由恒等式 (14.25)，对任意 $\boldsymbol{x},\boldsymbol{z}$，

$$\|\nabla f_\delta^{\mathrm{B}}(\boldsymbol{x}) - \nabla f_\delta^{\mathrm{B}}(\boldsymbol{z})\|_2 \le \frac{n}{\delta}\mathbb{E}|f(\boldsymbol{x}+\delta\boldsymbol{u}) - f(\boldsymbol{z}+\delta\boldsymbol{u})| \le \frac{nG}{\delta}\|\boldsymbol{x}-\boldsymbol{z}\|_2.$$

所以 f_δ^{B} 的光滑常数不超过 nG/δ。δ 越小，平滑目标越接近原目标，但也越弯曲。这个上界不一定紧，它的作用是说明平滑后有光滑常数可用。

14.3.3 双点估计

成对查询允许把单点估计里的大数减掉。在相反方向各读一次，得到**双点估计**（two-point estimator）：

$$\hat{\boldsymbol{g}}^{(2)} = \frac{n}{2\delta}(y_+ - y_-)\boldsymbol{u}, \qquad y_\pm = f(\boldsymbol{x} \pm \delta\boldsymbol{u}). \tag{14.28}$$

这正是第 14.2.2节的式 (14.15)取 $h=\delta$。公式相同，这里的解释却更精确。

为什么均值是平滑梯度 $\boldsymbol{u}$ 和 $-\boldsymbol{u}$ 同分布，所以单点估计用 $-\boldsymbol{u}$ 代替 $\boldsymbol{u}$，期望不变：

$$\frac{n}{\delta}\mathbb{E}\big[f(\boldsymbol{x}+\delta\boldsymbol{u})\boldsymbol{u}\big] = \frac{n}{\delta}\mathbb{E}\big[f(\boldsymbol{x}-\delta\boldsymbol{u})(-\boldsymbol{u})\big].$$

两式相加除以 2，右端正是 $\mathbb{E}[\hat{\boldsymbol{g}}^{(2)}]$，左端由恒等式等于 $\nabla f_\delta^{\mathrm{B}}(\boldsymbol{x})$。于是

$$\mathbb{E}\big[\hat{\boldsymbol{g}}^{(2)}\big] = \nabla f_\delta^{\mathrm{B}}(\boldsymbol{x}). \tag{14.29}$$

把两节的说法对照起来，同一个向量有两种读法。作为原梯度的近似，它有偏差，Hessian 是 Lipschitz 时偏差是 $O(\delta^2)$；作为平滑梯度的估计，它严格无偏。表 14.3列出两种读法的差别。选哪种读法，取决于最终想回答关于哪个目标的问题。

读法	估计对象	偏差
有限差分	$\nabla f(\boldsymbol{x})$	一般非零，随 δ 缩小
平滑估计	$\nabla f_\delta^{\mathrm{B}}(\boldsymbol{x})$	严格为零

表 14.3　同一个双点向量的两种读法。原目标不可微时第一种读法没有对象，第二种仍然成立。

减去中心值的形式　另一个双点形式把 y_- 换成中心读数：

$$\hat{\boldsymbol{g}}^{(\mathrm{c})} = \frac{n}{\delta}\big(f(\boldsymbol{x}+\delta\boldsymbol{u}) - f(\boldsymbol{x})\big)\boldsymbol{u}. \tag{14.30}$$

由 $\mathbb{E}[f(\boldsymbol{x})\boldsymbol{u}] = \boldsymbol{0}$，它的均值也是 $\nabla f_\delta^{\mathrm{B}}(\boldsymbol{x})$。两种形式都消除了常数偏移，贯穿例上把“很大的 45”去掉了。

二阶矩的比较　消去偏移后，估计的大小由差商决定。下面的引理针对光滑目标给出统一的界。

引理 14.9　双点估计的二阶矩　设 ∇f 是 L-Lipschitz 的，读数精确。对估计 (14.28)和 (14.30)，都有

$$\mathbb{E}\|\hat{\boldsymbol{g}}\|_2^2 \le 2n\|\nabla f(\boldsymbol{x})\|_2^2 + \frac{n^2L^2\delta^2}{2}. \tag{14.31}$$

证明　记 $\boldsymbol{g} = \nabla f(\boldsymbol{x})$，$\hat{\boldsymbol{g}} = nD\boldsymbol{u}$，其中 D 是对应的差商，写成 $D = \langle \boldsymbol{g}, \boldsymbol{u}\rangle + r$。由式 (14.9)或下降引理，两种形式都有 $|r| \le L\delta/2$。

用 $(a+b)^2 \le 2a^2 + 2b^2$ 和 $\|\boldsymbol{u}\|_2 = 1$，

$$\|\hat{\boldsymbol{g}}\|_2^2 = n^2D^2 \le 2n^2\langle \boldsymbol{g}, \boldsymbol{u}\rangle^2 + \frac{n^2L^2\delta^2}{2}.$$

取期望，再用 $\mathbb{E}[\boldsymbol{u}\boldsymbol{u}^{\top}] = \boldsymbol{I}/n$，得到结论。 ■

14.1 函数值反馈
14.2 有限差分
14.3 随机平滑与梯度估计
14.3.1 平滑目标
14.3.2 单点估计
14.3.3 双点估计
14.3.4 高斯方向估计
14.3.5 成对读数的噪声
14.4 零阶随机梯度方法
14.5 误差与查询成本
14.6 本章小结

式 (14.31)与单点的式 (14.27)对比，分母里的 δ^2 不见了，δ 可以取得很小而不使估计爆炸。这是精确读数下成对查询的实质收益。

两种双点形式的差别要看函数。贯穿例上，对称形式的差商精确等于方向导数，二阶矩是 $n\|\boldsymbol{g}\|_2^2$；中心形式多出 $\frac{\delta}{2}\boldsymbol{u}^{\top}\boldsymbol{H}\boldsymbol{u}$，二阶矩更大。在极小点 $\boldsymbol{g}=\boldsymbol{0}$ 处，对称形式的估计恒为零，而中心形式不为零，这点上对称形式完全不抖动。$f=|x|$ 在 $x=0$ 处，对称形式同样恒为零，中心形式的估计是 ± 1。

但是“方差改善”不是无条件的结论。第一，改善来自消去 f 的大小，如果 f 本身在零附近，单点估计并没有这部分额外的方差。第二，带独立噪声时，两次单点估计取平均与一次双点估计噪声贡献相同，都是 $n^2\sigma^2/(2\delta^2)$，第 14.3.5节会算出来。所以成对读数消去的是函数值的公共部分，不是噪声。

14.3.4 高斯方向估计

球面方向需要扰动恰好落在半径 δ 的球面上。如果改用高斯扰动，查询点不再被限制在球面上，分析也更简单，因为高斯密度的导数有封闭形式。

主要思想 作变量替换 $\boldsymbol{z}=\boldsymbol{x}+\tau\boldsymbol{w}$，把高斯平滑写成

$$f_\tau^{\mathrm{G}}(\boldsymbol{x})=\frac{1}{(2\pi\tau^2)^{n/2}}\int f(\boldsymbol{z})\exp\!\Big(-\frac{\|\boldsymbol{z}-\boldsymbol{x}\|_2^2}{2\tau^2}\Big)\mathrm{d}\boldsymbol{z}.$$

现在 $\boldsymbol{x}$ 只出现在指数里，f 不必可微，梯度全部落到光滑的高斯核上。这与球平滑的情况类似：导数从 f 转移到了平均方式上。

定理 14.10 高斯平滑的梯度恒等式 设 f 可测，存在 $C,a\ge 0$ 使 $|f(\boldsymbol{z})|$ 处处不超过 $Ce^{a\|\boldsymbol{z}\|_2}$，$\boldsymbol{w}\sim\mathcal{N}(\boldsymbol{0},\boldsymbol{I})$。则 f_τ^{G} 可微，且

$$\nabla f_\tau^{\mathrm{G}}(\boldsymbol{x})=\frac{1}{\tau}\,\mathbb{E}_{\boldsymbol{w}}\big[f(\boldsymbol{x}+\tau\boldsymbol{w})\,\boldsymbol{w}\big]. \tag{14.32}$$

证明 高斯核对 $\boldsymbol{x}$ 的梯度等于核本身乘 $(\boldsymbol{z}-\boldsymbol{x})/\tau^2$。当 $\boldsymbol{x}$ 在一个有界邻域内时，被积函数对 $\boldsymbol{x}$ 的梯度被一个不依赖 $\boldsymbol{x}$ 的可积函数控制：指数增长被高斯衰减压住。由控制收敛定理，可在积分号下求导，得

$$\nabla f_\tau^{\mathrm{G}}(\boldsymbol{x})=\frac{1}{(2\pi\tau^2)^{n/2}}\int f(\boldsymbol{z})\frac{\boldsymbol{z}-\boldsymbol{x}}{\tau^2}\exp\!\Big(-\frac{\|\boldsymbol{z}-\boldsymbol{x}\|_2^2}{2\tau^2}\Big)\mathrm{d}\boldsymbol{z}.$$

再换回 $\boldsymbol{z}=\boldsymbol{x}+\tau\boldsymbol{w}$，$(\boldsymbol{z}-\boldsymbol{x})/\tau^2=\boldsymbol{w}/\tau$，即得结论。 ■

这个定理比球面的恒等式要求的局部性质弱：f 可以不连续，因为积分覆盖整个空间，f 在零测集上的值不起作用。要求转移到了全局的增长上，这正好是定义中高斯平滑存在所需要的。

三种形式　抽一个 $\boldsymbol{w}$，式 (14.32)给出单点形式。与球面的情形一样，减去中心值或取对称差，均值不变：

$$\hat{\boldsymbol{g}}^{\mathrm{G}} = \frac{y}{\tau}\boldsymbol{w}, \qquad \hat{\boldsymbol{g}}^{\mathrm{Gc}} = \frac{y - f(\boldsymbol{x})}{\tau}\boldsymbol{w}, \qquad \hat{\boldsymbol{g}}^{\mathrm{Gs}} = \frac{y - y'}{2\tau}\boldsymbol{w}, \tag{14.33}$$

其中 $y = f(\boldsymbol{x} + \tau\boldsymbol{w})$，$y' = f(\boldsymbol{x} - \tau\boldsymbol{w})$。第二种利用了 $\mathbb{E}[\boldsymbol{w}] = \boldsymbol{0}$，第三种利用了 $\boldsymbol{w}$ 与 $-\boldsymbol{w}$ 同分布。

贯穿例起点，取 $\tau = 0.1$，抽到 $\boldsymbol{w} = (1, -0.5)$。对称形式的读数和差商是

$$f(9.1, 0.95) = 45.46625, \qquad f(8.9, 1.05) = 44.56625, \qquad \frac{y - y'}{2\tau} = 4.5.$$

这里 $\langle \nabla f, \boldsymbol{w} \rangle = 9 - 4.5 = 4.5$，吻合。估计是 $4.5\,\boldsymbol{w} = (4.5, -2.25)$。

与球面方向的区别　公式里没有因子 n，这是因为 $\mathbb{E}[\boldsymbol{w}\boldsymbol{w}^{\top}] = \boldsymbol{I}$，球面方向则是 $\boldsymbol{I}/n$。如果把球面的归一化照搬过来写成 $(n/\tau)y\boldsymbol{w}$，二次函数上的均值就变成 $n\nabla f$，整整放大 n 倍。

另一个区别是扰动的长度。$\|\boldsymbol{w}\|_2$ 是随机的，大约是 $\sqrt{n}$，如图 14.12(b)。τ 只是尺度，不是查询半径。$n = 2$ 时

$$\mathbb{P}\big(\|\boldsymbol{w}\|_2 > 3\big) = e^{-4.5} \approx 0.011,$$

一百次里约有一次偏离三个尺度。要与球面半径 δ 对应，应取 $\tau = \delta/\sqrt{n}$，这时 $\tau\boldsymbol{w}$ 的均方长度等于 δ^2。

14.1 函数值反馈
14.2 有限差分
14.3 随机平滑与梯度估计
14.3.1 平滑目标
14.3.2 单点估计
14.3.3 双点估计
14.3.4 高斯方向估计
14.3.5 成对读数的噪声
14.4 零阶随机梯度方法
14.5 误差与查询成本
14.6 本章小结

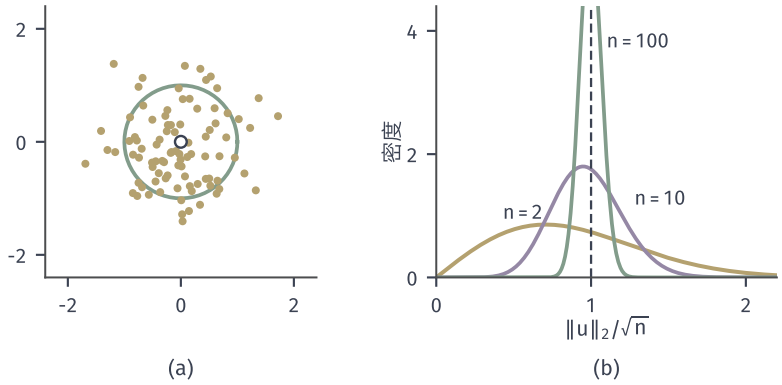


图 14.12 球面方向与高斯方向。(a)$n = 2$，绿圆是半径 $\delta = 1$ 的球面查询位置，黄点是尺度 $\tau = 1/\sqrt{2}$ 的高斯查询点，二者均方长度相同，高斯点散布在圆内外。(b)$\|\boldsymbol{w}\|_2/\sqrt{n}$ 的密度。维数增大时高斯方向的长度集中到 $\sqrt{n}$ 附近，$n = 2$ 时差异很大。

二次函数上，对称形式的二阶矩可以直接算：

$$\mathbb{E}\big[\langle \boldsymbol{g}, \boldsymbol{w}\rangle^2 \|\boldsymbol{w}\|_2^2\big] = (n+2)\|\boldsymbol{g}\|_2^2.$$

所以方差是 $(n+1)\|\boldsymbol{g}\|_2^2$，比球面方向的 $(n-1)\|\boldsymbol{g}\|_2^2$ 略大，多出来的部分来自长度的波动。一般光滑函数上有类似的上界：

$$\mathbb{E}\|\hat{\boldsymbol{g}}^{\mathrm{Gs}}\|_2^2 \le 2(n+2)\|\nabla f(\boldsymbol{x})\|_2^2 + \frac{L^2\tau^2}{2} n(n+2)(n+4). \tag{14.34}$$

推导与引理 14.9相同，只是余项是 $|r| \le L\tau\|\boldsymbol{w}\|_2^2/2$，再用高斯矩 $\mathbb{E}\|\boldsymbol{w}\|_2^6 = n(n+2)(n+4)$。

14.3.5 成对读数的噪声

到此为止的二阶矩都假设读数精确。本小节回到第 14.1.2节的接口问题：读数含噪声时，成对差分的波动是多少？

独立噪声 采用式 (14.7)，ζ_+, ζ_- 条件独立，均值零，方差不超过 σ^2。差商的噪声部分是 $(\zeta_+ - \zeta_-)/(2\delta)$，于是

$$\mathrm{Var}\Big(\frac{\zeta_+ - \zeta_-}{2\delta}\Big) \le \frac{\sigma^2}{2\delta^2}. \tag{14.35}$$

半径减半，方差变成四倍。噪声大小不随距离变小，分母却在变小。图 14.13中黄线的斜率是 -2。

噪声与差商主项的交叉项为零，因为噪声的条件均值是零。代入估计，$\|\hat{\boldsymbol{g}}^{(2)}\|_2^2$ 的期望增加 $n^2\sigma^2/(2\delta^2)$。结合引理 14.9，得到后面反复使用的二阶矩界：

$$\mathbb{E}\|\hat{\boldsymbol{g}}^{(2)}\|_2^2 \le 2n\|\nabla f(\boldsymbol{x})\|_2^2 + V, \qquad V = \frac{n^2L^2\delta^2}{2} + \frac{n^2\sigma^2}{2\delta^2}. \tag{14.36}$$

单点平均与成对差分 单点估计用两次独立读数和两个独立方向取平均时，噪声贡献是

$$\frac{1}{4}\Big(\frac{n^2\sigma^2}{\delta^2} + \frac{n^2\sigma^2}{\delta^2}\Big) = \frac{n^2\sigma^2}{2\delta^2},$$

与双点估计完全相同。这验证了前面的说法：独立噪声下，配对不减少噪声，只消去函数值的公共部分。

共享样本 采用式 (14.6)，差分的方差包含协方差：

$$\operatorname{Var}\big[F(\boldsymbol{q}_+;\boldsymbol{\xi}) - F(\boldsymbol{q}_-;\boldsymbol{\xi})\big] = \operatorname{Var}F_+ + \operatorname{Var}F_- - 2\operatorname{Cov}(F_+, F_-). \tag{14.37}$$

共享样本带来的是正的协方差，协方差越大，抵消越多。若两个噪声的相关系数是 ρ 且方差都是 σ^2，差的方差是 $2\sigma^2(1-\rho)$，从 $\rho=0$ 的独立到 $\rho=1$ 的完全抵消，中间是连续变化的。

三个例子 共享样本的效果取决于样本函数本身的波动。

第一个例子是两点共享同一个加性噪声，$F(\boldsymbol{x};\xi) = f(\boldsymbol{x}) + \xi$。差分时 ξ 完全消失，噪声方差为零，无论半径多小，差商都是精确的。

第二个例子是样本函数关于 $\boldsymbol{x}$Lipschitz，比如 $F(\boldsymbol{x};\boldsymbol{\xi}) = f(\boldsymbol{x}) + \boldsymbol{\xi}^{\top}\boldsymbol{x}$。差分的随机部分是

$$\frac{\boldsymbol{\xi}^{\top}(\boldsymbol{q}_+ - \boldsymbol{q}_-)}{2\delta} = \boldsymbol{\xi}^{\top}\boldsymbol{u},$$

它不依赖 δ。一般地，若 $F(\cdot;\boldsymbol{\xi})$ 是 Lipschitz 的，常数为 $G(\boldsymbol{\xi})$，差商的二阶矩不超过 $\mathbb{E}[G(\boldsymbol{\xi})^2]$，$\delta$ 可以取得很小。图 14.13中绿线是水平的。

第三个例子是样本函数不连续。$F(x;\xi) = \mathbb{1}\{x > \xi\}$，$\xi$ 的密度为 p。共享 ξ 时差分只在 $\xi \in [x-h, x+h)$ 时非零，概率约 $2hp(x)$，于是差商方差约为

$$\frac{2hp(x)}{4h^2} = \frac{p(x)}{2h}.$$

它比独立噪声的 $1/h^2$ 好，但仍随 h 缩小而增大，图 14.13中紫线的斜率是 -1。所以共享样本带来改善的前提是差值的波动受控，只说“用了同一个种子”并不够。

14.1 函数值反馈
14.2 有限差分
14.3 随机平滑与梯度估计
14.4 零阶随机梯度方法
14.4.1 基本迭代
14.4.2 步长与扰动尺度
14.4.3 约束下的查询
14.4.4 输出与停止
14.5 误差与查询成本
14.6 本章小结

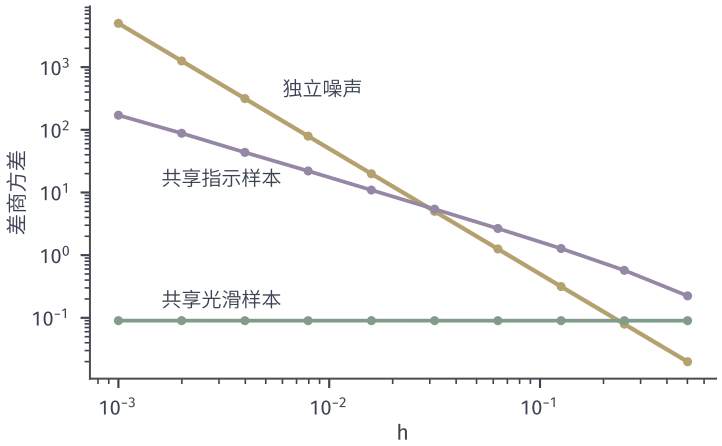


图 14.13 中心差商的方差随 h 的变化，$x = 0.5$。黄线：独立加性噪声，标准差 0.1，斜率 -2。紫线：共享指示样本 $F = \mathbb{1}\{x > \xi\}$，$\xi \sim \mathcal{N}(0,1)$，斜率 -1。绿线：共享光滑样本 $F = x^2/2 + \xi x$，ξ 标准差 0.3，方差不随 h 变化。共享同一加性噪声时方差为零，未画出。每点来自 4×10^6 次模拟。

14.4 零阶随机梯度方法

前两节构造了各种方向估计。接下来要弄清：把它们放进迭代后，算法实际在优化什么，步长和扰动尺度怎样定，遇到约束怎么办，最后交出什么结果？

14.4.1 基本迭代

主要思想 第 13章的随机更新沿随机方向 $\hat{\boldsymbol{g}}^{(t)}$ 的负向走一步。它能用的原因是，这个方向平均起来指向某个函数的梯度。零阶方法沿用这个更新，只是 $\hat{\boldsymbol{g}}^{(t)}$ 由函数值算出：

$$\boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} - \alpha^{(t)} \hat{\boldsymbol{g}}^{(t)}, \qquad \hat{\boldsymbol{g}}^{(t)} = \frac{n}{2\delta}\left(y_+^{(t)} - y_-^{(t)}\right)\boldsymbol{u}^{(t)}. \tag{14.38}$$

这是**零阶随机梯度方法**（zeroth-order stochastic gradient method）的双点形式，其他估计器可以替换第二式。一轮的流程如图 14.14所示。

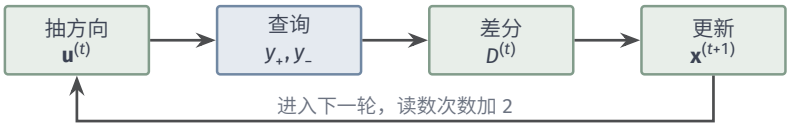


图 14.14 双点零阶方法的一轮。绿框是算法内部的计算，蓝框是向黑箱提交的查询。每轮两次函数读数，查询预算按读数次数累计。

更新形式都一样，算法朝哪里走却由估计器的条件均值决定，不能只看形式。式 (14.38)的条件均值是 $\nabla f_\delta^{\mathrm{B}}(\boldsymbol{x}^{(t)})$，所以它是平滑目标上的随机梯度方法，不是原目标上的。

变量

- $\boldsymbol{x}^{(t)} \in \mathbb{R}^n$：当前迭代点。
- $\boldsymbol{u}^{(t)} \in \boldsymbol{S}$：本轮的单位方向，$n$ 维。
- $y_{\pm}^{(t)}$：两次读数，标量。
- $D^{(t)} = (y_{+}^{(t)} - y_{-}^{(t)})/(2\delta)$：差商，标量。
- $\hat{\boldsymbol{g}}^{(t)} \in \mathbb{R}^n$：方向估计。
- α、δ：步长与扰动半径，取常数。
- Q：已用读数次数。

初始化 取起点 $\boldsymbol{x}^{(0)}$，选定 α、δ 和读数预算 $Q_{\max}$，令 $Q = 0$。例中目标是贯穿例 (14.1)，读数带独立噪声，并取

$$\boldsymbol{x}^{(0)} = (9, 1), \quad \alpha = 0.05, \quad \delta = 0.5, \quad Q_{\max} = 6.$$

每轮更新　下面的数值用事先给定的方向和噪声，便于逐项核对。

1. 抽取方向 $\boldsymbol{u}^{(t)}$。例中第一轮 $\boldsymbol{u}^{(0)} = (0.6, 0.8)$，第二轮 $\boldsymbol{u}^{(1)} = (0.8, -0.6)$，第三轮 $\boldsymbol{u}^{(2)} = (0.28, 0.96)$。

2. 查询 $\boldsymbol{x}^{(t)} \pm \delta \boldsymbol{u}^{(t)}$，$Q$ 增加 2。例中第一轮两个查询点是 $(9.3, 1.4)$ 和 $(8.7, 0.6)$，真实函数值为 52.065 和 39.465，噪声分别为 $+0.1$ 和 -0.1，读数是

$$y_{+}^{(0)} = 52.165, \qquad y_{-}^{(0)} = 39.365.$$

3. 由式 (14.38)算差商和方向估计。例中 $2\delta = 1$，$n = 2$，第一轮结果是

$$D^{(0)} = 12.8, \qquad \hat{\boldsymbol{g}}^{(0)} = 2 \cdot 12.8 \cdot (0.6, 0.8) = (15.36,\ 20.48).$$

4. 由式 (14.38)沿 $-\hat{\boldsymbol{g}}^{(t)}$ 走步长 α。例中第一轮得到

$$\boldsymbol{x}^{(1)} = (9, 1) - 0.05\,(15.36, 20.48) = (8.232,\ -0.024).$$

第二轮从 $\boldsymbol{x}^{(1)}$ 出发，查询点是 $(8.632, -0.324)$ 和 $(7.832, 0.276)$，噪声是 -0.1 和 $+0.1$，读数和结果为

$$y_{+}^{(1)} \approx 37.628, \quad y_{-}^{(1)} \approx 31.113, \quad D^{(1)} \approx 6.515,$$

$$\hat{\boldsymbol{g}}^{(1)} \approx (10.424,\ -7.818), \qquad \boldsymbol{x}^{(2)} \approx (7.711,\ 0.367).$$

第三轮查询点是 $(7.851, 0.847)$ 和 $(7.571, -0.113)$，噪声是 $+0.05$ 和 $+0.15$，读数和结果为

$$y_{+}^{(2)} \approx 34.095, \quad y_{-}^{(2)} \approx 28.866, \quad D^{(2)} \approx 5.229,$$

$$\hat{\boldsymbol{g}}^{(2)} \approx (2.928,\ 10.040), \qquad \boldsymbol{x}^{(3)} \approx (7.564,\ -0.135).$$

迭代在 Q 达到 $Q_{\max}$ 时结束。例中三轮用完 6 次读数，最终得到 $\boldsymbol{x}^{(3)} \approx (7.564, -0.135)$，真实目标值约 28.69，从 45 下降了三分之一多。第二轮的梯度第二分量只有 -0.216，估计的第二分量却是 -7.818，x_2 从 -0.024 跳到 0.367，这种摆动是单方向估计的常态。继续运行的结果见图 14.15。

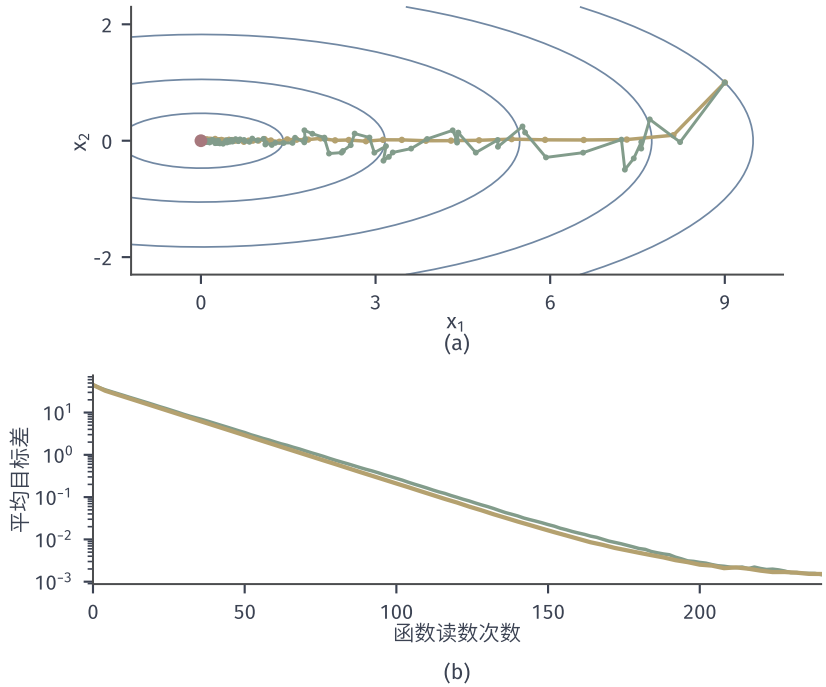


图 14.15 贯穿例上的零阶迭代，读数噪声标准差 0.1。(a) 绿线是双点球面方法的一次运行，$\alpha = 0.05$，$\delta = 0.5$，前三轮即正文手算的数据，共 120 轮；黄线是中心坐标差分的梯度下降，$\alpha = 0.1$，$h = 0.5$，共 60 轮；蓝线是等高线，红点是解。(b)200 次运行的平均目标差，横轴是函数读数次数。

图 14.15(a) 中绿线抖动，黄线平稳，但按读数次数算两者几乎重合，如图 14.15(b)。这里两者的步长不同：单方向估计的步长要比完整梯度小一个与 n 相关的倍数，原因在第 14.4.2节说明。

多方向平均 每轮抽 m 个独立方向，分别计算估计后取平均，是最常见的变体，一轮用 $2m$ 次读数：

$$\hat{\boldsymbol{g}}^{(t)} = \frac{1}{m}\sum_{j=1}^{m} \frac{n}{2\delta}\left(y_{j,+}^{(t)} - y_{j,-}^{(t)}\right)\boldsymbol{u}_j^{(t)}. \tag{14.39}$$

条件均值不变，方差变成 $1/m$。例中第一轮若用 $\boldsymbol{u}_1 = (0.6, 0.8)$ 和 $\boldsymbol{u}_2 = (0.8, -0.6)$ 两个方向，不计噪声时，两个估计是

$$(15.12,\ 20.16), \qquad (2.88,\ -2.16).$$

它们的平均恰为 $(9, 9)$，这时 $\boldsymbol{x}^{(1)} = (8.55, 0.55)$。两个方向正交且数量等于维数，对二次函数恰好拼出了完整梯度。

一步分析：有偏与无偏两条路 把估计器代入迭代，有两种分析方式，对应前面的两种读法。先假设 ∇f 是 L-Lipschitz 的，第一种直接看原目标。

14.1 函数值反馈
14.2 有限差分
14.3 随机平滑与梯度估计
14.4 零阶随机梯度方法
14.4.1 基本迭代
14.4.2 步长与扰动尺度
14.4.3 约束下的查询
14.4.4 输出与停止
14.5 误差与查询成本
14.6 本章小结

引理 14.11　单步下降　设 $\boldsymbol{x}^+ = \boldsymbol{x} - \alpha\hat{\boldsymbol{g}}$，$\nabla f$ 是 L-Lipschitz 的。若 $\hat{\boldsymbol{g}}$ 的条件均值是 $\nabla f(\boldsymbol{x}) + \boldsymbol{b}$，且 $\|\boldsymbol{b}\|_2 \le \beta$，则

$$\mathbb{E}[f(\boldsymbol{x}^+) \mid \boldsymbol{x}] \le f(\boldsymbol{x}) - \frac{\alpha}{2}\|\nabla f(\boldsymbol{x})\|_2^2 + \frac{\alpha}{2}\beta^2 + \frac{L\alpha^2}{2}\mathbb{E}\big[\|\hat{\boldsymbol{g}}\|_2^2 \mid \boldsymbol{x}\big]. \tag{14.40}$$

若 $\hat{\boldsymbol{g}}$ 的条件均值是 $\nabla f_\delta^{\mathrm{B}}(\boldsymbol{x})$，则

$$\mathbb{E}[f_\delta^{\mathrm{B}}(\boldsymbol{x}^+) \mid \boldsymbol{x}] \le f_\delta^{\mathrm{B}}(\boldsymbol{x}) - \alpha\|\nabla f_\delta^{\mathrm{B}}(\boldsymbol{x})\|_2^2 + \frac{L\alpha^2}{2}\mathbb{E}\big[\|\hat{\boldsymbol{g}}\|_2^2 \mid \boldsymbol{x}\big]. \tag{14.41}$$

证明　由下降引理，对 L-光滑函数 ψ，

$$\psi(\boldsymbol{x}^+) \le \psi(\boldsymbol{x}) - \alpha\langle\nabla\psi(\boldsymbol{x}), \hat{\boldsymbol{g}}\rangle + \frac{L\alpha^2}{2}\|\hat{\boldsymbol{g}}\|_2^2.$$

取 $\psi = f$ 并取条件期望，内积项变为 $-\alpha\|\nabla f\|_2^2 - \alpha\langle\nabla f, \boldsymbol{b}\rangle$。再用

$$-\langle\nabla f, \boldsymbol{b}\rangle \le \frac{1}{2}\|\nabla f\|_2^2 + \frac{1}{2}\beta^2,$$

得式 (14.40)。

取 $\psi = f_\delta^{\mathrm{B}}$，由引理 14.7，它也是 L-光滑的，内积项的条件期望是 $-\alpha\|\nabla f_\delta^{\mathrm{B}}\|_2^2$，得式 (14.41)。 ■

两式对比可以看出两种分析的差别。式 (14.40)留下了偏差项 $\frac{\alpha}{2}\beta^2$，它每步都存在，累加后构成不会随步数消失的误差。式 (14.41)没有偏差项，账记在平滑目标上，代价是结论说的是 f_δ^{B}，要回到 f 还须另算，这留给第 14.5.3节。

14.4.2 步长与扰动尺度

这里有两个旋钮。步长 α 决定参数实际走多远，扰动尺度 δ 决定在多大的邻域里比较函数值。两者的量纲都不同：改变 δ 不移动 $\boldsymbol{x}$，只改变估计的性质。

步长的上限　由式 (14.36)，二阶矩中有 $2n\|\nabla f\|_2^2$，比完整梯度的 $\|\nabla f\|_2^2$ 大 $2n$ 倍。代入式 (14.41)，要让下降项压住二阶矩项，需要 $\alpha \lesssim 1/(nL)$。直观地说，估计的长度波动约为梯度的 $\sqrt{n}$ 倍，步长必须相应地收小。

这个步长要与每轮的读数次数放在一起看。完整坐标差分的步长是 $1/L$，但每轮要 $2n$ 次读数；单方向的步长是 $1/(nL)$，每轮 2 次读数。按读数次数算，两者每次读数的“进展”同阶，这就是图 14.15(b) 中两条曲线重合的原因。

贯穿例的手算用了 $\alpha = 0.05 < 1/(nL) = 1/18$。下一小节定理要求的 $\alpha \le 1/(4nL) = 1/72$ 更保守，这是为了在任意光滑函数上保证下降，实际使用时常可放宽。

固定尺度对应固定的平滑目标 δ 固定时，迭代是同一个 f_δ^{B} 上的随机梯度方法，所以固定步长最终会停在一个噪声水平上。图 14.16(a) 在贯穿例上取 $\alpha = 0.02$，噪声 $\sigma = 1$，分别用 $\delta = 0.1, 0.5, 2$。

三条曲线下降段相同，稳定后的水平差别很大，δ 从 0.1 增大到 0.5，水平约下降 25 倍。这正是式 (14.36)中 V 的噪声项 $n^2\sigma^2/(2\delta^2)$ 的 $1/\delta^2$ 规律。这个例子是二次函数，平滑没有引入任何偏差，所以 δ 越大越好；一般函数上 δ 还有偏差的代价，第 14.5.1节讨论。

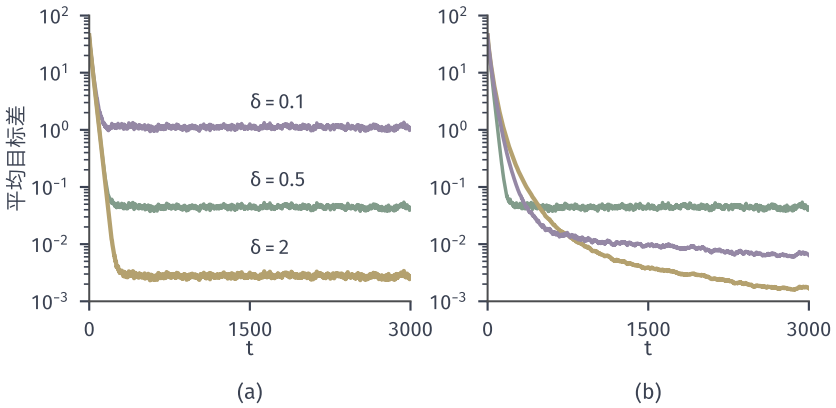


图 14.16 贯穿例上双点方法的平均目标差，读数噪声 $\sigma = 1$，300 次运行。(a) 固定 $\alpha = 0.02$，紫、绿、黄三线分别为 $\delta = 0.1, 0.5, 2$，稳定水平按 $1/\delta^2$ 变化。(b)$\delta = 0.5$ 时固定 $\alpha = 0.02$（绿）；步长递减 $\alpha^{(t)} = 0.02/(1 + t/100)$（黄）；步长递减较慢、尺度也递减，$\alpha^{(t)} = 0.02/(1 + t/100)^{0.75}$，$\delta^{(t)} = 0.5/(1 + t/100)^{0.1}$（紫）。

递减步长 要越过这个水平，步长必须递减，这与第 13章的情形相同。图 14.16(b) 的黄线就是在 δ 固定时让步长递减，曲线继续下降。

逐步缩小尺度要多记两笔 既然小的 δ 偏差小，能否让 $\delta^{(t)}$ 随迭代缩小？可以，但目标函数本身在变，分析要多记两笔。

第一笔是目标的变化。第 t 步看的是 $f_{\delta^{(t)}}^{\mathrm{B}}$，下一步换成 $f_{\delta^{(t+1)}}^{\mathrm{B}}$，累加时不再是同一个函数相减，多出差值 $f_{\delta^{(t+1)}}^{\mathrm{B}} - f_{\delta^{(t)}}^{\mathrm{B}}$。若 $\delta^{(t+1)} \le \delta^{(t)}$，由式 (14.22)，这个差值的绝对值不超过 $L(\delta^{(t)})^2$，一般情形要把它们加起来，$\sum_t (\delta^{(t)})^2$ 必须受控。

凸函数的情形方便一些。设 $\delta_1 \le \delta_2$，$\lambda = \delta_1/\delta_2$。由凸性，

$$f(\boldsymbol{x} + \delta_1 \boldsymbol{v}) \le \lambda f(\boldsymbol{x} + \delta_2 \boldsymbol{v}) + (1 - \lambda) f(\boldsymbol{x}).$$

取期望并用 $f \le f^{\mathrm{B}}_{\delta_2}$，得

$$f^{\mathrm{B}}_{\delta_1} \le f^{\mathrm{B}}_{\delta_2}.$$

所以缩小半径时平滑目标只降不升，这一笔差值对凸函数不造成损失。

第二笔是方差的变化。V 里的噪声项是 $n^2\sigma^2/(2(\delta^{(t)})^2)$，缩小 δ 会放大方差，步长必须缩得更快，抵消这部分增长。累加式 (14.41)可见需要控制的是 $\sum_t (\alpha^{(t)})^2 V^{(t)}$，因此独立噪声下的标准要求是

$$\sum_{t} \alpha^{(t)} = \infty, \qquad \sum_{t} \Big(\frac{\alpha^{(t)}}{\delta^{(t)}}\Big)^2 < \infty, \qquad \delta^{(t)} \to 0. \tag{14.42}$$

前一个条件保证能走得足够远，后一个条件是随机逼近步长条件的变形[1]。，分母上多了 $\delta^{(t)}$，反映差商的噪声放大。图 14.16(b) 的紫线步长递减更慢，尺度也在缩小，两者都使噪声项更大，所以高于黄线。这个二次函数上 δ 没有偏差可减，缩小尺度没有收益，这也说明 δ 是否该缩小要看偏差。

14.1 函数值反馈
14.2 有限差分
14.3 随机平滑与梯度估计
14.4 零阶随机梯度方法
14.4.1 基本迭代
14.4.2 步长与扰动尺度
14.4.3 约束下的查询
14.4.4 输出与停止
14.5 误差与查询成本
14.6 本章小结

[1] H. Robbins, S. Monro, *A Stochastic Approximation Method* In The Annals of Mathematical Statistics, 1951, vol. 22, no. 3, pp. 400–407

14.4.3 约束下的查询

约束问题要多考虑一件事：不光更新点要可行，查询点也可能需要可行。仿真器在非法参数下可能崩溃，物理实验在限制之外可能损坏设备。

更新可行不等于查询可行 投影更新

$$\boldsymbol{x}^{(t+1)} = \Pi_{\boldsymbol{C}}\big(\boldsymbol{x}^{(t)} - \alpha \hat{\boldsymbol{g}}^{(t)}\big)$$

保证了迭代点在 $\boldsymbol{C}$ 内，但没有限制查询点。以 $\boldsymbol{C} = [1,9]\times[-1,1]$ 为例，$\boldsymbol{x} = (1, 0.4)$ 在边界上，取 $\delta = 0.2$，$\boldsymbol{u} = (0.6, 0.8)$，两个查询点是

$$\boldsymbol{x} + \delta\boldsymbol{u} = (1.12,\ 0.56), \qquad \boldsymbol{x} - \delta\boldsymbol{u} = (0.88,\ 0.24).$$

第二个点的 $x_1 < 1$，越出了可行域，如图 14.17(a)。投影把迭代点拉回来，却管不到这一步。

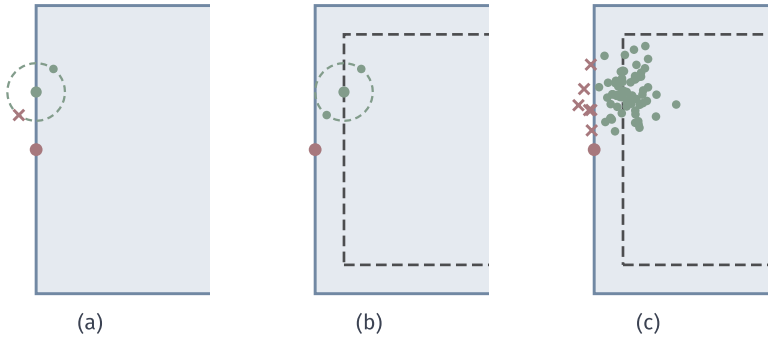


图 14.17 可行域 $\boldsymbol{C}=[1,9]\times[-1,1]$ 的左端（浅蓝），红点是贯穿例在 $\boldsymbol{C}$ 上的解 $(1,0)$，绿点是迭代点和可行的查询点，红叉是越界查询。(a) 迭代点在边界上，半径 0.2 的查询圆（绿色虚线）越界，$(0.88,0.24)$ 不可行。(b) 把迭代点限制在内缩域（灰色虚线），查询圆完全在 $\boldsymbol{C}$ 内。(c) 同样的内缩域，尺度 $\tau=\delta/\sqrt{2}$ 的高斯扰动仍有查询点越界。

收缩查询区域 解决办法是把迭代点限制在一个内缩的区域里，让半径 δ 的球放得下。设凸集 $\boldsymbol{C}$ 含有以原点为心、半径 r 的球，即 $r\boldsymbol{B}\subseteq\boldsymbol{C}$。令 $\theta=\delta/r\in(0,1)$，取收缩集合

$$\boldsymbol{C}_\theta=(1-\theta)\boldsymbol{C}. \tag{14.43}$$

定理 14.12 收缩集合的查询可行性与边界误差 设 $\boldsymbol{C}$ 是凸集，$r\boldsymbol{B}\subseteq\boldsymbol{C}$，$\theta=\delta/r<1$。则对 $\boldsymbol{x}\in\boldsymbol{C}_\theta$ 和 $\boldsymbol{v}\in\boldsymbol{B}$，有 $\boldsymbol{x}+\delta\boldsymbol{v}\in\boldsymbol{C}$。若 f 在 $\boldsymbol{C}$ 上是凸函数，$\boldsymbol{x}^\star\in\boldsymbol{C}$ 是解，则

$$\min_{\boldsymbol{x}\in\boldsymbol{C}_\theta} f(\boldsymbol{x})-f^\star\le\theta\big(f(\boldsymbol{0})-f^\star\big). \tag{14.44}$$

证明 设 $\boldsymbol{x}=(1-\theta)\boldsymbol{c}$，$\boldsymbol{c}\in\boldsymbol{C}$。则

$$\boldsymbol{x}+\delta\boldsymbol{v}=(1-\theta)\boldsymbol{c}+\theta\,(r\boldsymbol{v}),$$

这里用了 $\delta=\theta r$。右端是 $\boldsymbol{C}$ 中两点 $\boldsymbol{c}$ 和 $r\boldsymbol{v}$ 的凸组合，所以在 $\boldsymbol{C}$ 中。

误差界：$(1-\theta)\boldsymbol{x}^\star\in\boldsymbol{C}_\theta$，由凸性，

$$f\big((1-\theta)\boldsymbol{x}^\star+\theta\boldsymbol{0}\big)\le(1-\theta)f^\star+\theta f(\boldsymbol{0}).$$

移项即得。 ■

定理的条件中，内部球不可少：r 越小，同样的 δ 需要收缩得越多，$\boldsymbol{C}$ 没有内点时完全无法在 $\boldsymbol{C}$ 内做全维扰动。凸性用在了两处，凸组合的可行性和最后的误差界。

14.1 函数值反馈
14.2 有限差分
14.3 随机平滑与梯度估计
14.4 零阶随机梯度方法
14.4.1 基本迭代
14.4.2 步长与扰动尺度
14.4.3 约束下的查询
14.4.4 输出与停止
14.5 误差与查询成本
14.6 本章小结

继续上面的例子，以 $(5,0)$ 为中心平移，$\boldsymbol{C}$ 含半径 $r=1$ 的球。$\delta=0.2$ 时 $\theta=0.2$，$\boldsymbol{C}_\theta=[1.8,8.2]\times[-0.8,0.8]$。解 $(1,0)$ 被挡在外面，$\boldsymbol{C}_\theta$ 上最好的点是 $(1.8,0)$，代价是 $f(1.8,0)-f(1,0)=1.12$，定理的上界是 $0.2\cdot(12.5-0.5)=2.4$。按比例收缩对长边很不划算。

如果知道 $\boldsymbol{C}$ 的形状，直接用内缩集 $\{\boldsymbol{x}:\boldsymbol{x}+\delta\boldsymbol{B}\subseteq\boldsymbol{C}\}$ 更好。这里它是 $[1.2,8.8]\times[-0.8,0.8]$，如图 14.17(b)，代价只有 $f(1.2,0)-f(1,0)=0.22$。

收缩产生的误差要计入最终结果：算法解的是 $\boldsymbol{C}_\theta$ 上的问题，δ 越大这笔误差越大，同时噪声方差越小，这是约束情形下多出来的一层取舍。

高斯扰动的问题 高斯分布的支撑是全空间，从任何一点出发都有正概率越界，如图 14.17(c)，收缩多少都无法消除。要用高斯扰动，必须有办法在域外查询：比如 f 有明确的域外延拓，且恒等式 (14.32)所需的增长条件在延拓后成立，那么平滑目标就是延拓函数的平滑。

如果域外不能查询，把越界的点投影回来或截断分布都会改变查询点的分布，恒等式不再成立，需要另行设计估计器并重新分析它的偏差。

14.4.4 输出与停止

迭代结束时要交出一个点，并且说明它满足什么保证。下面先给无约束情形的两个基本结论，它们的累加方式与一阶方法相同，只是二阶矩换成了零阶估计的二阶矩。

光滑非凸情形 非凸目标上只能期望梯度变小。迭代序列上最小的梯度无法用读数辨认，所以常用随机返回：事先在 $\{0,\dots,T-1\}$ 上均匀抽取下标 R，输出 $\boldsymbol{x}^{(R)}$[2]。这样输出点的期望恰好等于全部迭代的平均。

定理 14.13 光滑非凸目标 设 ∇f 是 L-Lipschitz 的，$f\ge f_{\inf}$，读数带独立噪声，方差不超过 σ^2（$\sigma=0$ 为精确读数）。迭代 (14.38)取常数 $\alpha\le 1/(4nL)$，常数 $\delta>0$。记

$$\Delta_\delta=f_\delta^{\mathrm{B}}(\boldsymbol{x}^{(0)})-f_{\inf},\qquad W=4nL^2\delta^2+V, \tag{14.45}$$

其中 V 见式 (14.36)。则

$$\mathbb{E}\left\|\nabla f_\delta^{\mathrm{B}}(\boldsymbol{x}^{(R)})\right\|_2^2\le\frac{2\Delta_\delta}{\alpha T}+L\alpha W. \tag{14.46}$$

[2] S. Ghadimi, G. Lan, *Stochastic First- and Zeroth-Order Methods for Nonconvex Stochastic Programming* In SIAM Journal on Optimization, 2013, vol. 23, no. 4, pp. 2341–2368

证明 由引理 14.7，∇f 与 $\nabla f_\delta^{\mathrm{B}}$ 至多相差 $L\delta$，于是

$$\|\nabla f\|_2^2 \le 2\|\nabla f_\delta^{\mathrm{B}}\|_2^2 + 2L^2\delta^2.$$

代入式 (14.36)，二阶矩不超过 $4n\|\nabla f_\delta^{\mathrm{B}}\|_2^2 + W$。

代入式 (14.41)，并由 $\alpha \le 1/(4nL)$ 得 $2nL\alpha^2 \le \alpha/2$，于是

$$\mathbb{E}[f_\delta^{\mathrm{B}}(\boldsymbol{x}^+) \mid \boldsymbol{x}] \le f_\delta^{\mathrm{B}}(\boldsymbol{x}) - \frac{\alpha}{2}\|\nabla f_\delta^{\mathrm{B}}(\boldsymbol{x})\|_2^2 + \frac{L\alpha^2}{2}W.$$

取全期望，对 $t = 0, \dots, T-1$ 累加，左端相消，由 $f_\delta^{\mathrm{B}} \ge f_{\inf}$ 得

$$\frac{\alpha}{2}\sum_{t=0}^{T-1}\mathbb{E}\|\nabla f_\delta^{\mathrm{B}}(\boldsymbol{x}^{(t)})\|_2^2 \le \Delta_\delta + \frac{TL\alpha^2}{2}W.$$

除以 $\alpha T/2$，左端就是随机返回点的期望。 ■

光滑凸情形 凸目标上有明确的目标差，常用迭代平均 $\bar{\boldsymbol{x}} = \frac{1}{T}\sum_{t=0}^{T-1}\boldsymbol{x}^{(t)}$ 作为输出。

定理 14.14 光滑凸目标 设 f 是凸函数，∇f 是 L-Lipschitz 的，解 $\boldsymbol{x}^\star$ 存在，$R_0 = \|\boldsymbol{x}^{(0)} - \boldsymbol{x}^\star\|_2$，读数条件与 V 同定理 14.13。取 $\alpha \le 1/(4nL)$，则

$$\mathbb{E} f_\delta^{\mathrm{B}}(\bar{\boldsymbol{x}}) - f_\delta^{\mathrm{B}}(\boldsymbol{x}^\star) \le \frac{R_0^2}{\alpha T} + \alpha V + \frac{L\delta^2}{2}. \tag{14.47}$$

证明 记

$$a = f(\boldsymbol{x}) - f^\star \ge 0, \qquad e = f_\delta^{\mathrm{B}}(\boldsymbol{x}) - f_\delta^{\mathrm{B}}(\boldsymbol{x}^\star).$$

展开距离并用无偏性，得

$$\mathbb{E}\|\boldsymbol{x}^+ - \boldsymbol{x}^\star\|_2^2 = \|\boldsymbol{x} - \boldsymbol{x}^\star\|_2^2 - 2\alpha\langle \nabla f_\delta^{\mathrm{B}}(\boldsymbol{x}), \boldsymbol{x} - \boldsymbol{x}^\star\rangle + \alpha^2\mathbb{E}\|\hat{\boldsymbol{g}}\|_2^2.$$

f_δ^{B} 是凸函数，内积不小于 e。f 是 L-光滑的凸函数，$\|\nabla f\|_2^2 \le 2La$，所以二阶矩不超过 $4nLa + V$。

由 $f_\delta^{\mathrm{B}} \ge f$ 和式 (14.22)，$e \ge a - L\delta^2/2$。把 $-2\alpha e$ 拆成两半，其中一半用这个下界：

$$-2\alpha e \le -\alpha e - \alpha a + \frac{\alpha L\delta^2}{2}.$$

再由 $\alpha \le 1/(4nL)$，$4nL\alpha^2 a \le \alpha a$，两个含 a 的项相互抵消，得到

$$\mathbb{E}\|\boldsymbol{x}^{+} - \boldsymbol{x}^{\star}\|_2^2 \le \|\boldsymbol{x} - \boldsymbol{x}^{\star}\|_2^2 - \alpha e + \frac{\alpha L \delta^2}{2} + \alpha^2 V.$$

累加 T 轮后除以 αT，再由 f_δ^{B} 的凸性和 Jensen 不等式转到 $\bar{\boldsymbol{x}}$。 ■

两个定理都假设了读数的独立噪声和光滑性，换成共享样本时，V 要按第 14.3.5节重新计算。定理说的都是平滑目标上的量，第 14.5.3节负责换算回原目标。

约束情形　有约束时，梯度不必为零，应该看投影后是否还能移动。对闭凸集 $\boldsymbol{C}'$，定义残差

$$\boldsymbol{r}_\alpha(\boldsymbol{x}) = \frac{1}{\alpha}\big(\boldsymbol{x} - \Pi_{\boldsymbol{C}'}(\boldsymbol{x} - \alpha \nabla f(\boldsymbol{x}))\big). \tag{14.48}$$

$\boldsymbol{r}_\alpha(\boldsymbol{x}) = \boldsymbol{0}$ 恰好表示 $\boldsymbol{x}$ 是 $\boldsymbol{C}'$ 上的一阶驻点。凸问题可以沿用定理 14.14证明中的累加，投影的非扩张性使距离递推依然成立，$\boldsymbol{x}^\star$ 换成 $\boldsymbol{C}'$ 中的比较点。不同的是约束解处梯度一般不为零，不能再用 $\|\nabla f\|_2^2 \le 2La$，要改用 $\boldsymbol{C}'$ 上的梯度上界 G_0，二阶矩换成 $2nG_0^2 + V$，步长按此选取。

非凸约束情形要谨慎：投影是非线性的，单方向估计的方差不会在残差中平均掉，通常要用每轮方向数随总轮数增长的多方向平均，才能得到残差的保证。证明需要逐轮控制投影残差的方差，篇幅较长，读者可查阅随机投影方法的相关文献；这里需要记住的是，无约束的结论不能直接搬用。

三种不同的停止依据　“什么时候停”有三种根据，含义不同。

第一种是预算耗尽。这是实际中最常见的依据，也是唯一确定能执行的，但它什么也不保证。

第二种是函数值暂时不变。连续若干轮读数变化很小，可能是到了最优点附近，也可能是走进了一片平坦区域，或者步长太小，或者读数精度不够。比如读数按整数舍入时，小步长下读数完全不变，而函数并没有到达极小。这个信号不等于驻点。

第三种是驻点保证。定理 14.13这类保证是期望意义的，由假设和步数推出，不来自运行中的观测，因为算法读不到真实梯度，含噪的估计也远比梯度大。

含噪目标的比较需要复评　含噪读数下，有一个常见的陷阱：把历史上读数最低的点当作最好的点。图 14.18(a) 中 12 个候选真实值全都是 1，选读数最低的那个，读数看起来远远低于 1，其实只是噪声最负的一个。

14.1 函数值反馈
14.2 有限差分
14.3 随机平滑与梯度估计
14.4 零阶随机梯度方法
14.5 误差与查询成本
14.5.1 扰动尺度的取舍
14.5.2 维数与方向数
14.5.3 原目标的误差评价
14.5.4 函数评估总成本
14.6 本章小结

设 K 个候选真实值相同，读数噪声独立标准正态。最小读数的期望低于真值：$K=2$ 时低 $1/\sqrt{\pi}\approx 0.56$ 倍标准差，$K=10$ 时约 1.54 倍，$K=100$ 时约 2.51 倍，如图 14.18(b)。这种偏差称为**选择偏差**（selection bias）。

解决办法是**独立复评**（independent re-evaluation）：选定候选之后，用新的读数重新评价，这些新读数与选择过程无关，因此无偏。r 次复评的平均，标准差是 $\sigma/\sqrt{r}$，r 要计入总预算。如果不复评，报告结果时要说明它带有这个偏差。

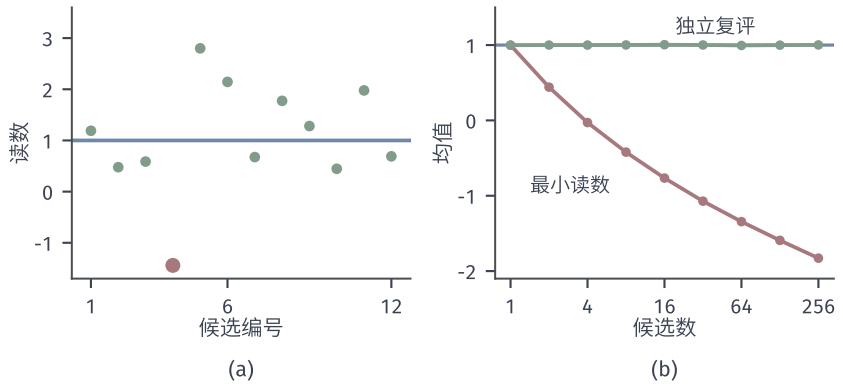


图 14.18　含噪比较的选择偏差，真实值都是 1（蓝线），噪声为标准正态。(a)12 个候选的一次读数，红点是读数最低者，它并不比其他候选好。(b) 红线是 K 个候选中最小读数的均值，随 K 增大而偏低；绿线是选定后独立复评的均值，始终等于真值。每点 10^5 次模拟。

14.5 误差与查询成本

前面记下了各种误差的账，本节把它们合并。要解决的问题是：给定函数读数的总预算，误差由哪几部分构成，各种方法怎样比较，平滑问题上的结论又怎样回到原问题？比较时固定同一个评价预算，分开记录三种误差：平滑或差分偏差、随机方向误差和读数噪声。

14.5.1 扰动尺度的取舍

差商的 U 形曲线　扰动太大，差商在量一段弯曲路径的平均坡度；扰动太小，一点噪声就被放大。这两股力量相反，总误差随尺度呈 U 形。

取均方误差分析。前向差商在二阶导有上界 L 时，偏差不超过 $Lh/2$；中心差商在三阶导有上界 M 时，偏差不超过 $Mh^2/6$。结合式 (14.11)，独立噪声下的均方误差满足

$$\mathrm{MSE}_{\mathrm{F}}(h)\le \frac{L^2h^2}{4}+\frac{2\sigma^2}{h^2},\qquad \mathrm{MSE}_{\mathrm{C}}(h)\le \frac{M^2h^4}{36}+\frac{\sigma^2}{2h^2}. \tag{14.49}$$

第二项随 h 平方的倒数增长，这对独立的加性噪声是不可避免的。对两式右端关于 h 求导并令其为零，得到最优尺度

$$h_{\mathrm{F}} = \left(\frac{8\sigma^2}{L^2}\right)^{1/4}, \qquad h_{\mathrm{C}} = \left(\frac{3\sigma}{M}\right)^{1/3}. \tag{14.50}$$

继续用 $\varphi(s) = s^2/2 + s^3/6$，$s_0 = 1$，这里局部取 $L = \varphi''(1) = 2$，$M = 1$，噪声 $\sigma = 0.01$。代入式 (14.50)，得到

$$h_{\mathrm{F}} \approx 0.119, \qquad h_{\mathrm{C}} \approx 0.311.$$

最优点上的均方根误差分别约为 0.17 和 0.028，如图 14.19。差别不只在数值：中心差分可以用更大的 h，这同时削弱了噪声放大，所以在噪声存在时收益比精确读数时更明显。

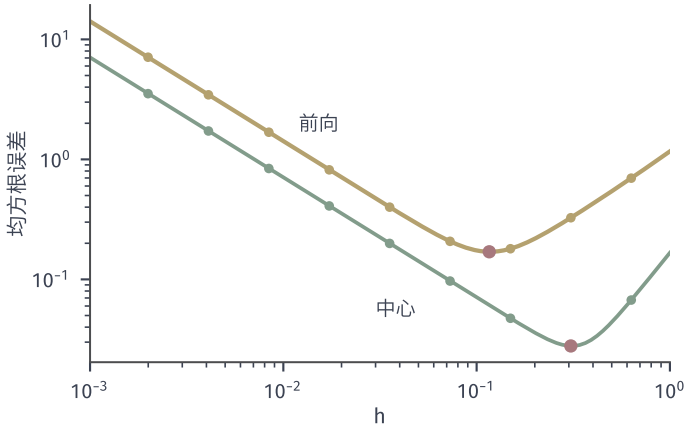


图 14.19 差商均方根误差随 h 的变化，$\varphi(s) = s^2/2 + s^3/6$，$s_0 = 1$，独立噪声 $\sigma = 0.01$。黄线为前向差分，绿线为中心差分，曲线是偏差平方加方差的精确值，圆点是 2×10^5 次模拟的结果，红点是各自的最小值。h 小时两线斜率都是 -1，h 大时分别是 1 和 2。

迭代中的同一取舍 在迭代算法中，平滑半径受同样的取舍支配，但记账的单位变了。定理 14.14的上界对 δ 的依赖是 $\alpha V + L\delta^2/2$，而 V 里的噪声项 $\propto 1/\delta^2$。

图 14.20用一个非二次的凸目标 $f(\boldsymbol{x}) = \sum_{i=1}^{2}(e^{x_i} - x_i - 1)$ 做实验，解是原点，$f^\star = 0$，算法跑固定轮数，噪声 $\sigma = 0.2$。δ 小的一侧，误差按 $1/\delta^2$ 增长，来自噪声；δ 大的一侧，平滑目标的解偏离原点，误差快速上升。最好的 δ 在 0.5 附近，目标差约 0.0026，$\delta = 0.02$ 和 $\delta = 4$ 时都超过 1。

14.1 函数值反馈
14.2 有限差分
14.3 随机平滑与梯度估计
14.4 零阶随机梯度方法
14.5 误差与查询成本
14.5.1 扰动尺度的取舍
14.5.2 维数与方向数
14.5.3 原目标的误差评价
14.5.4 函数评估总成本
14.6 本章小结

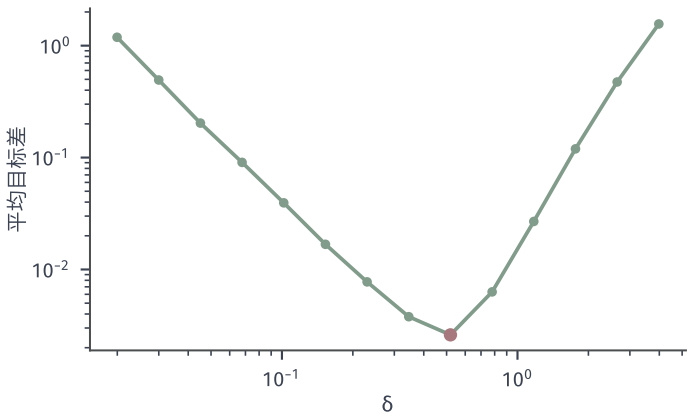


图 14.20 双点方法在 $f(\boldsymbol{x}) = \sum_{i=1}^{2}(e^{x_i} - x_i - 1)$ 上的平均目标差随 δ 的变化，起点 $(1,1)$，$\alpha = 0.02$，$\sigma = 0.2$，$T = 3000$，取最后 500 步的平均，200 次运行。左支由噪声放大主导，右支由平滑偏差主导，红点是扫描到的最小值。

共享样本时规律不同 上面的 $1/\delta^2$ 规律只适用于独立加性噪声。共享的 Lipschitz 样本下，差商的方差不随 δ 增大而爆炸，δ 可以尽量取小，U 形曲线的左支几乎消失。而指示函数样本的方差 $\propto 1/\delta$，左支依然存在，只是坡度减半。用哪个 δ 要先确定噪声模型。

14.5.2 维数与方向数

“每轮只读两次”常被误解成成本与维数无关。上面的 $\alpha \lesssim 1/(nL)$ 已经说明，维数并没有消失，只是从每轮的读数次数转移到了步长上。

单轮比较 表 14.4比较完整坐标差分和随机方向在单轮的成本与误差。这里的“方向波动”是读数精确时二次函数上的 $\mathbb{E}\|\hat{\boldsymbol{g}} - \boldsymbol{g}\|_2^2$。

方法	单轮读数	方向波动	独立噪声贡献
中心坐标	$2n$	0	$n\sigma^2/(2h^2)$
单方向对称	2	$(n-1)\|\boldsymbol{g}\|_2^2$	$n^2\sigma^2/(2\delta^2)$
m 方向对称	$2m$	$(n-1)\|\boldsymbol{g}\|_2^2/m$	$n^2\sigma^2/(2m\delta^2)$
m 方向共用中心	$m+1$	取决于函数	$2n^2\sigma^2/(m\delta^2)$

表 14.4 一轮估计的成本与误差。$m = n$ 时，随机方向的噪声贡献与中心坐标差分相同，都是 $n\sigma^2/(2\delta^2)$，读数次数也相同。

相同预算下的结果 图 14.21在 $n = 20$ 的二次目标上比较三种配置，步长按单轮二阶矩调节：坐标差分用 $1/L$，m 方向平均用 $1/(L(1+(n-1)/m))$。横轴都是函数读数次数。读数精确时三条线基本平行，图 (a)；读数含噪时停在几乎同一水平，图 (b)。

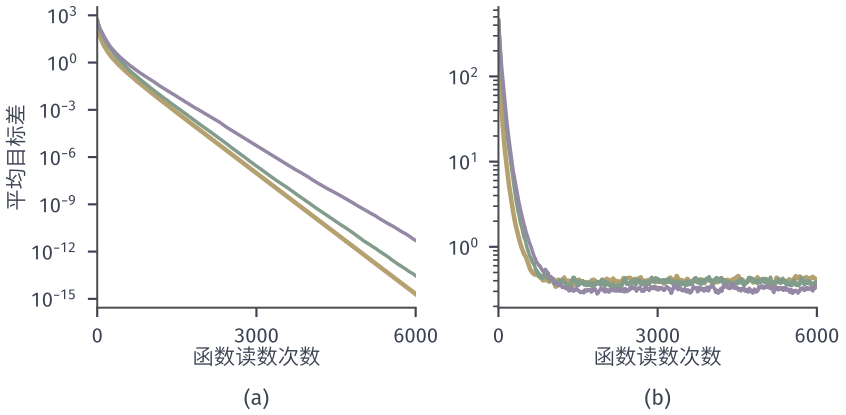


图 14.21 $n = 20$ 的二次目标，$\boldsymbol{H}$ 的对角元从 1 均匀到 9，$h = \delta = 0.1$，30 次运行平均。黄线：中心坐标差分。绿线：$m = 1$ 的随机方向。紫线：$m = 5$ 的随机方向。(a) 读数精确。(b) 独立噪声 $\sigma = 0.1$。按读数次数计，三者的差别远小于“两次查询对 40 次查询”的字面差距。

这个实验的结论有范围。它说明在按读数计费、读数可独立提交的情形下，每轮少读并不等于总成本少。随机方向的优势在别处：可以在读完所有坐标之前就开始移动。梯度集中在少数方向时效果可能更好，但这取决于具体结构，本章没有相应的定理。反过来，如果读数可并行、每轮墙钟时间固定，完整差分反而可能更快。

方向平均与共用中心读数 独立方向平均把方差除以 m，这部分依赖独立性。为节省读数，有人让所有方向共用一次中心读数 $y_0 = f(\boldsymbol{x}) + \zeta_0$，读数次数从 $2m$ 降到 $m + 1$。这时

$$\hat{\boldsymbol{g}} = \frac{n}{\delta m} \sum_{j=1}^{m} (y_j - y_0) \boldsymbol{u}_j,$$

噪声部分是 $\frac{n}{\delta m} \sum_j (\zeta_j - \zeta_0) \boldsymbol{u}_j$。给定方向，$\zeta_0$ 对所有方向是同一个数，噪声不再独立，二阶矩是

$$\frac{n^2 \sigma^2}{\delta^2 m^2} \Big(m + \Big\| \sum_{j=1}^{m} \boldsymbol{u}_j \Big\|_2^2 \Big).$$

方向独立随机时 $\mathbb{E} \| \sum_j \boldsymbol{u}_j \|_2^2 = m$，总贡献是 $2n^2\sigma^2/(m\delta^2)$，与每方向单独读中心点的情形相同。方向相关时，比如都偏向同一侧，第二项可以高达 m^2。所以共用中心读数引入了相关性，必须单独计入。

坐标方向上这一点最清楚。前向坐标差分共用 $f(\boldsymbol{x})$ 时，噪声的协方差是

$$\frac{\sigma^2}{h^2} (\boldsymbol{I} + \mathbf{1}\mathbf{1}^{\top}),$$

14.1 函数值反馈
14.2 有限差分
14.3 随机平滑与梯度估计
14.4 零阶随机梯度方法
14.5 误差与查询成本
14.5.1 扰动尺度的取舍
14.5.2 维数与方向数
14.5.3 原目标的误差评价
14.5.4 函数评估总成本
14.6 本章小结

它的特征值是 $(n+1)\sigma^2/h^2$（对应方向 $\mathbf{1}$）和 $n-1$ 个 σ^2/h^2。公共噪声把误差压到一个方向上，如图 14.22(a)，而中心差分的误差是各向同性的，如图 (b)。

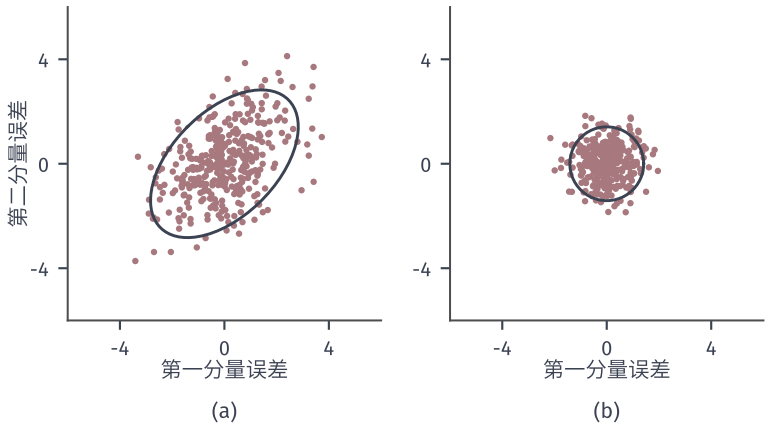


图 14.22 $n=2$，$\sigma=h=0.1$ 时坐标差分的噪声误差。红点是 350 次模拟，黑色椭圆是两倍标准差的等概率线。(a) 前向差分共用中心读数，协方差 $\begin{bmatrix}2&1\\1&2\end{bmatrix}$，误差沿 $(1,1)$ 方向拉长。(b) 中心差分，协方差为 $\frac{1}{2}\boldsymbol{I}$。

14.5.3 原目标的误差评价

第 14.4.4节的定理说的都是平滑目标。原来要解决的问题是最小化 f，本小节补上这一步。

函数平滑误差 设平滑目标 f_s 与 f 处处至多相差 γ_f，这个常数 γ_f 是**函数平滑误差**（function smoothing error）。由引理 14.7，光滑函数的球平滑可取 $\gamma_f = L\delta^2/2$，G-Lipschitz 函数可取 $\gamma_f = G\delta$。

定理 14.15 从平滑目标回到原目标 设 $|f_s - f| \le \gamma_f$，$\boldsymbol{x}^\star$ 是 f 的解，则对任意 $\hat{\boldsymbol{x}}$，

$$f(\hat{\boldsymbol{x}}) - f^\star \le f_s(\hat{\boldsymbol{x}}) - f_s(\boldsymbol{x}^\star) + 2\gamma_f. \tag{14.51}$$

若两者的梯度处处至多相差 γ_g（按欧氏范数），则

$$\|\nabla f(\hat{\boldsymbol{x}})\|_2^2 \le 2\|\nabla f_s(\hat{\boldsymbol{x}})\|_2^2 + 2\gamma_g^2. \tag{14.52}$$

证明 由一致误差的假设，

$$f(\hat{\boldsymbol{x}}) \le f_{\mathrm{s}}(\hat{\boldsymbol{x}}) + \gamma_f, \qquad f_{\mathrm{s}}(\boldsymbol{x}^\star) \le f^\star + \gamma_f.$$

两式相加移项得式 (14.51)。

由三角不等式，$\|\nabla f\|_2$ 不超过 $\|\nabla f_{\mathrm{s}}\|_2 + \gamma_g$，两边平方并用 $(a+b)^2 \le 2a^2 + 2b^2$，得式 (14.52)。 ■

式 (14.51)中的 $2\gamma_f$ 在凸函数上可以省一半，因为 $f \le f_\delta^{\mathrm{B}}$。把定理 14.14代回，对光滑凸目标得到

$$\mathbb{E} f(\bar{\boldsymbol{x}}) - f^\star \le \frac{R_0^2}{\alpha T} + \alpha V + L\delta^2. \tag{14.53}$$

把定理 14.13代回，取 $\gamma_g = L\delta$，对光滑非凸目标得到

$$\mathbb{E}\left\|\nabla f(\boldsymbol{x}^{(R)})\right\|_2^2 \le \frac{4\Delta_\delta}{\alpha T} + 2L\alpha W + 2L^2\delta^2. \tag{14.54}$$

平滑目标的解不是原目标的解 这个换算的 γ_f 是不能省的。取 $f(x) = \max\{x, -2x\}$，$n = 1$，$\delta = 1$，解是 $x^\star = 0$。$|x| < 1$ 时，平滑目标的导数是

$$\left(f_\delta^{\mathrm{B}}\right)'(x) = \frac{f(x+1) - f(x-1)}{2} = \frac{3x-1}{2},$$

零点在 $x = 1/3$，如图 14.23(a)。平滑目标的精确解带着原目标差 $f(1/3) = 1/3$。原目标两侧的斜率不对称，平均之后最低点向缓的一侧移动。这笔误差不是算法或噪声造成的，平滑的定义本身就带来了它。

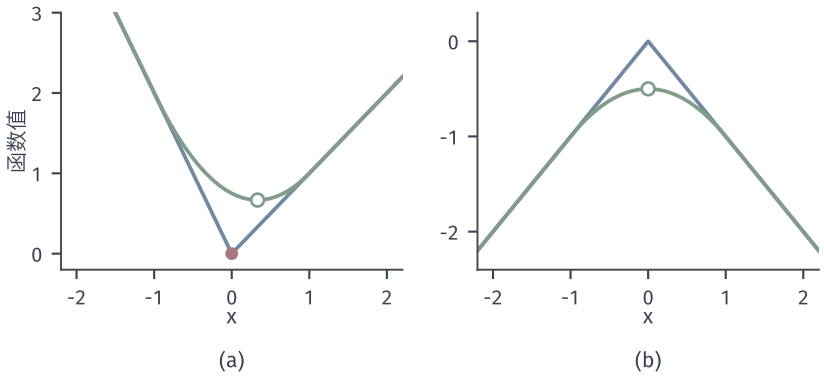


图 14.23 平滑目标（绿）与原目标（蓝）的差别，$\delta = 1$，一维区间平均。(a)$f(x) = \max\{x, -2x\}$，原解是红点 $x = 0$，平滑目标的解是空心点 $x = 1/3$，不在原解上。(b)$f(x) = -|x|$，平滑后在 $x = 0$ 处导数为零（空心点），而 $x = 0$ 是原函数的极大点。

14.1 函数值反馈
14.2 有限差分
14.3 随机平滑与梯度估计
14.4 零阶随机梯度方法
14.5 误差与查询成本
14.5.1 扰动尺度的取舍
14.5.2 维数与方向数
14.5.3 原目标的误差评价
14.5.4 函数评估总成本
14.6 本章小结

原目标不光滑时要换驻点的概念 式 (14.52)需要 ∇f 存在且 γ_g 有限。原目标不可微时，平滑梯度小不能说明原目标梯度小。回到 $f=|x|$，由 $\big(f_\delta^{\mathrm{B}}\big)'(x)=x/\delta$，在 $x=0.01\delta$ 处平滑导数只有 0.01，而原函数在此处的导数是 1。

平滑梯度小给出的是另一种结论。f 是 Lipschitz 时，$\nabla f_\delta^{\mathrm{B}}(\boldsymbol{x})$ 是 δ 邻域内各点梯度的平均，所以它小，说明邻域内的梯度有一个小的平均。这是 Goldstein 意义下的 δ 驻点，比经典驻点弱。

这也不保证全局最优。图 14.23(b) 的 $f=-|x|$，平滑后 $x=0$ 处导数为零，而 $x=0$ 恰恰是原函数的极大点。更一般的多谷目标上，平滑可能磨掉一些浅谷，但没有定理保证平滑目标的驻点在全局最优点附近。

14.5.4 函数评估总成本

成本的组成 一次优化消耗的函数读数总数是

$$Q=T\cdot m\cdot q\cdot r+Q_{\mathrm{eval}},\tag{14.55}$$

其中 T 是迭代轮数，m 是每轮方向数，q 是每方向的查询次数，r 是每个查询点的重复测量次数，Q_{eval} 是最终复评的开销。

取 $T=200$，$m=2$，$q=2$，$r=3$，末了对 5 个候选各复评 20 次，代入式 (14.55)，得到

$$Q=200\cdot 2\cdot 2\cdot 3+5\cdot 20=2500.$$

重复测量 r 和扰动尺度 δ 都能减小差商的噪声，但是方式不同：r 把方差除以 r，代价是读数翻 r 倍；增大 δ 不需要额外读数，但引入偏差。

并行耗时与评估总量 总量 Q 和实际等待时间是两个量。如果有 12 个并行的仿真槽，上例每轮的 12 次读数可同时提交，迭代部分需要 200 个批次，复评 100 次需要 9 个批次，总共 209 批。单线运行时就是 2500 次。比较算法时要说明用的是哪一个。并行时完整差分的劣势大大减小，甚至可能占优，因为它的每一轮都同时做完。

达到指定精度的成本 下面把前面的上界解出来，得到达到精度 ε 所需的读数量级。σ 是独立噪声的标准差。

读数精确且 f 是 L-光滑凸函数时，由式 (14.53)，$V=n^2L^2\delta^2/2$。取 $\alpha=1/(4nL)$，上界是

$$\frac{4nLR_0^2}{T}+\Big(\frac{n}{8}+1\Big)L\delta^2.$$

δ 可以任意小，只受浮点精度的限制。取 $\delta^2 \le \varepsilon/((2+n/4)L)$，$T = 8nLR_0^2/\varepsilon$，每轮两次读数，得到

$$Q = \frac{16\, nLR_0^2}{\varepsilon}.$$

梯度下降需要 $O(LR_0^2/\varepsilon)$ 次梯度，这里多出的正是因子 n，同完整坐标差分的成本同阶。

独立噪声下，由式 (14.53)和 $V \approx n^2\sigma^2/(2\delta^2)$，把步长调到最优后上界约为

$$2R_0\sqrt{\frac{V}{T}} + L\delta^2 = \frac{\sqrt{2}R_0 n\sigma}{\delta\sqrt{T}} + L\delta^2.$$

对 δ 求最小，得 $\delta \propto T^{-1/6}$，误差 $\varepsilon \propto T^{-1/3}$，反解 T 得到 $Q = O(LR_0^2 n^2\sigma^2/\varepsilon^3)$。这里 δ 必须随预算一起缩小，否则 $L\delta^2$ 这项不消失。这是第 14.5.1节 U 形曲线在迭代算法中的结果。

只有单点反馈且 f 是 G-Lipschitz 凸函数、$|f| \le B$ 时，二阶矩是 n^2B^2/δ^2，平滑误差是 $G\delta$。同样的累加分析给出误差约 $R_0 nB/(\delta\sqrt{T}) + G\delta$，最优化 δ 后 $\varepsilon \propto T^{-1/4}$。

光滑非凸情形按式 (14.54)同样处理。精确读数时取足够小的 δ，$\alpha = 1/(4nL)$，得 $Q = O(nL\Delta/\varepsilon^2)$，这里 Δ 是初始目标与下界之差。独立噪声时平衡 δ，得 $\varepsilon^2 \propto T^{-1/3}$，反解得表中的量级。

表 14.5汇总这些结果。

反馈与正则性	估计器	读数量级
精确，L-光滑凸	双点球面	nLR_0^2/ε
精确，L-光滑非凸	双点球面	$nL\Delta/\varepsilon^2$
独立噪声，L-光滑凸	双点球面	$LR_0^2 n^2\sigma^2/\varepsilon^3$
独立噪声，L-光滑非凸	双点球面	$L^3\Delta n^2\sigma^2/\varepsilon^6$
单点，G-Lipschitz 凸，$\lvert f\rvert \le B$	单点球面	$n^2R_0^2B^2G^2/\varepsilon^4$
共享 Lipschitz 样本，凸	双点球面	$n^2G^2R_0^2/\varepsilon^2$

表 14.5　本章简单估计器达到精度 ε 的读数量级，略去常数。凸问题的精度指目标差，非凸问题指 $\|\nabla f\|_2 \le \varepsilon$；末行由 $\|\hat{\boldsymbol{g}}\|_2 \le nG$ 的粗略界得到。这些都是上界，不是问题本身的下界。

表的最后一行可以改进。利用球面上 Lipschitz 函数的集中不等式，双点估计的二阶矩能够改进到 $O(nG^2)$，读数量级相应地变成 $nG^2R_0^2/\varepsilon^2$。这一步的证明需要用到球面集中不等式，篇幅较长，读者可查阅 Duchi 等人及 Shamir 关于双点反馈的工作。它的含义是：共享样本下，配对的收益是把维数从平方降到一次方。

14.1 函数值反馈
14.2 有限差分
14.3 随机平滑与梯度估计
14.4 零阶随机梯度方法
14.5 误差与查询成本
14.6 本章小结

比较时要留意三件事。一是接口：表中的噪声列不能跨行混用，独立噪声的速率不适用于共享样本，反之亦然。二是度量：目标差和梯度范数的 ε 不是一回事。三是假设：更好的指数往往需要更强的光滑性和更复杂的估计器，不是换一个步长就能得到。

14.6 本章小结

本章在只能读函数值的条件下回答了怎样构造方向、怎样迭代、最后得到什么保证。函数值反馈先要说清接口：精确值、加性噪声和样本函数是三种读数模型，单点与成对、独立噪声与共享样本是不同的读取条件，算法抽方向的随机性与读数的随机性分开记录。

局部方向有两种读法。有限差分以原梯度为对象：坐标差分需要 $n+1$ 或 $2n$ 次读数，随机方向差分和 SPSA 只需两次，但一条方向只有一条方向的信息，有限扰动下一般有偏，SPSA 的坐标尺度乘以 $\sqrt{n}$ 才是位移长度。随机平滑以平滑目标为对象：球平滑的恒等式 (14.25)和高斯平滑的恒等式 (14.32)给出严格无偏的估计，单点估计受函数值大小影响，双点估计消去常数偏移。独立噪声让差商方差按 $1/\delta^2$ 增长，共享样本是否改善取决于差值的波动。

把估计器代入迭代后，算法实际优化的目标由条件均值决定。步长受维数限制约为 $1/(nL)$，扰动尺度决定平滑目标和噪声，缩小它要同时记入目标变化和方差增长。约束下要分清更新可行与查询可行，球形扰动可用收缩集合，高斯扰动有无界支撑。输出按问题选择平均点或随机返回点，预算耗尽、读数不变和驻点保证是不同的停止依据，含噪比较需要独立复评。

按读数计费时，两次查询并不代表成本与维数无关，因子 n 转移到了步长上。平滑目标上的结论要加上平滑误差才是原目标的结论，原目标不光滑时平滑梯度小只是较弱的驻点概念，也不保证全局最优。选择方法时，先看接口：能读坐标且读数便宜就用差分；扰动必须同时施加时用 SPSA；只有单点反馈时用单点估计；能共享样本时优先双点估计并尽量取小 δ。

高斯平滑的恒等式也可以看作：把 $\boldsymbol{x}$ 当作高斯搜索分布的均值，这个估计描述均值移动时平均目标的变化。第 15章继续讨论怎样更新搜索分布和种群，那里的方法不都等同于本章的零阶梯度下降。

15.1 搜索问题
15.1.1 搜索空间
15.1.2 搜索状态
15.2 模拟退火
15.3 演化策略
15.4 遗传算法
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

第 15 章

随机搜索

要安排一批车辆的出发顺序，或者调一台模拟程序的几个开关和旋钮，每试一组方案，都只能得到一个代价数字。没有梯度，顺序和开关也谈不上求导；代价随方案的变化还可能高低起伏，朝眼前更好的方向走几步就停在一个局部低谷里。这时能做的，是决定下一批试哪些方案，以及怎样利用已经试过的结果。

第 14章用函数值构造局部方向，仍然沿着一条路径向下走。本章换一种组织方式：不估计方向，而是管理候选。把这种方式统称为**随机搜索**（random search）：用随机提议产生候选，用评价结果决定保留什么，再由保留下来的信息安排后续的提议。

下面先固定问题，看清局部改善为什么会停。然后依次讨论四类方法，它们的差别在于保存什么、怎样更新：模拟退火只保存一个状态，靠接受规则决定要不要走；演化策略保存一个高斯分布，靠选择结果调整它的中心和形状；遗传算法保存一个种群，靠编码上的交叉和变异重组已有候选；粒子群让每个候选带着速度和记忆移动。

后三节处理所有方法共有的问题：候选不可行时怎么办，读数有噪声时最好记录还能不能信，结果应当怎样报告。全章反复用到两个小例子，一个是七个状态的双谷代价，一个是二维多峰函数，手算的步骤都在这些例子上进行。

15.1 搜索问题

只能评价候选时，搜索到底在面对什么？先把目标、允许的候选和一次评价的回报固定下来，再看局部改善为什么会停滞。

目标、候选和一次评价　全章考虑的问题写成

$$\min_{\boldsymbol{x}\in\boldsymbol{C}} f(\boldsymbol{x}), \tag{15.1}$$

其中 $\boldsymbol{C}$ 是允许的候选集合，f 是待最小化的代价，$f^\star$ 和 $\boldsymbol{x}^\star$ 是最优值和最优解。$\boldsymbol{C}$ 可以是 $\mathbb{R}^n$ 的一块区域，也可以是有限集合，比如所有长度为 n 的 0–1 串，或者 n 个元素的所有排列。

算法与问题之间只有一种接触方式：提交一个候选 $\boldsymbol{x}$，收到一个数。这叫一次**评价**（evaluation）。收到的数不告诉我们 f 在别处的取值，也不带梯度或曲率。全章把预算记作 B，表示允许的评价总次数；字母 T 留给后面的温度。

局部改善为什么会停　看一个最小的例子。状态集合是 $\{1, 2, \dots, 7\}$，每个状态只与左右相邻的状态相连，代价是

$$\big(f(1), f(2), \dots, f(7)\big) = (3,\ 1,\ 3,\ 5,\ 2,\ 0,\ 2). \tag{15.2}$$

全局最小在 $x = 6$，代价为 0；$x = 2$ 是另一个低谷，代价为 1。两个低谷之间隔着代价为 5 的 $x = 4$。

规则“只走向更低的邻居”从 $x = 3$ 出发，下一步到 $x = 2$。在 $x = 2$，两个邻居的代价都是 3，都比当前高，于是永远停在这里。从 $1, 2, 3$ 出发都停在 $x = 2$，从 $4, 5, 6, 7$ 出发才能到达 $x = 6$。七个状态里有三个起点拿不到最优解，而算法在 $x = 2$ 上收不到任何“还有更好的地方”的信号。这就是图 15.1(a)。

连续变量也一样。考虑二维的 Rastrigin 函数

$$f(\boldsymbol{x}) = 20 + \sum_{i=1}^{2} \big(x_i^2 - 10\cos(2\pi x_i)\big). \tag{15.3}$$

全局最小在原点，$f^\star = 0$。余弦项在每个整数点附近挖出一个小坑，在 $[-5.12, 5.12]^2$ 内共有 $11^2 = 121$ 个局部极小点。

图 15.1(b) 从四个起点运行梯度下降，每条路径都很快落进离起点最近的小坑。例如从 $(-2.3, 2.6)$ 出发，终点约为 $(-1.99, 2.98)$，那里的代价约为 12.9。梯度下降在那里做的是对的事情，梯度也确实趋于零，只是这个驻点离全局最小还很远。

15.1 搜索问题
15.1.1 搜索空间
15.1.2 搜索状态
15.2 模拟退火
15.3 演化策略
15.4 遗传算法
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

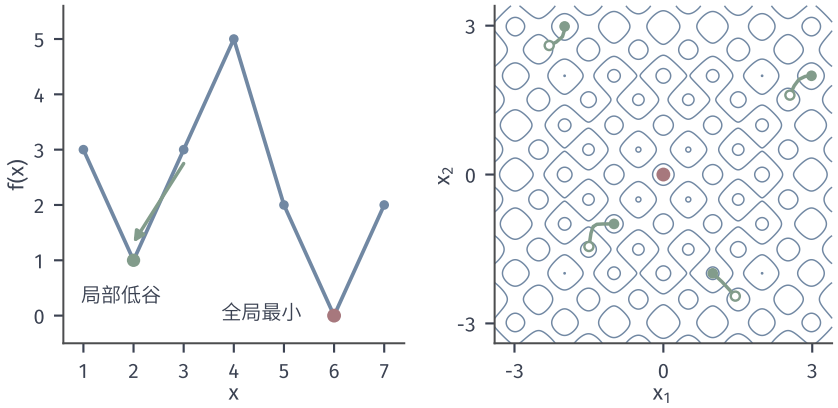


图 15.1 两个多谷的代价。(a) 七状态双谷代价 (15.2)，绿色箭头是从 $x = 3$ 出发的下降，绿点是停止处，红点是全局最小。(b) 二维 Rastrigin 函数 (15.3)的等高线（$f = 8, 24, 40$），绿色曲线是从四个空心起点运行的梯度下降，它们都停在邻近的局部极小点（绿色实心点），红点是全局最小点。

要越过这样的障碍，算法必须做一些眼前并不划算的事：接受更差的候选，或者同时在多个地方试探。本章各方法的差别就在这里。

三个不同的数 讨论算法时要分清三个数，它们经常被混为一谈。第一个是**真实目标值** $f(\boldsymbol{x})$，这是问题真正关心的量。

第二个是**读数**。评价可能含有噪声，这时收到的是

$$\tilde{f}(\boldsymbol{x}) = f(\boldsymbol{x}) + \varepsilon, \tag{15.4}$$

其中 ε 是这一次评价的误差。无噪声时 $\tilde{f} = f$。第 15.7节之前都设无噪声。

第三个是**历史最好记录**。算法运行到第 t 次评价时，把已见的可行候选中读数最低的那个单独存下来：

$$\begin{aligned} \boldsymbol{x}_{\text{best}}^{(t)} &\in \arg\min\{\tilde{f}(\boldsymbol{x}^{(s)}) : s \le t,\ \boldsymbol{x}^{(s)} \in \boldsymbol{C}\}, \\ f_{\text{best}}^{(t)} &= \min_{s \le t,\, \boldsymbol{x}^{(s)} \in \boldsymbol{C}} \tilde{f}(\boldsymbol{x}^{(s)}). \end{aligned} \tag{15.5}$$

无噪声时 $f_{\text{best}}^{(t)}$ 是真实值，而且随 t 不增。有噪声时它只是“最幸运的读数”，第 15.7节专门讨论这个差别。

15.1.1 搜索空间

同一个问题有不同的方式描述“从这个候选能走到哪里”。这一小节的问题是：候选的表示和移动方式怎样决定了搜索能到达什么地方？

三种候选，三种移动 连续参数 $\boldsymbol{x} \in \mathbb{R}^n$ 上最常用的移动是扰动 $\boldsymbol{x} + \sigma\boldsymbol{z}$，其中 $\boldsymbol{z}$ 是随机向量，$\sigma > 0$ 控制尺度。一步可以到达的候选充满 $\boldsymbol{x}$ 周围的一片区域。

二进制串 $\boldsymbol{b} \in \{0,1\}^n$ 上的基本移动是翻位：改变一位。长度为 n 的串恰有 n 个翻位邻居，任何两个串之间相差几位，就至少需要几次翻位。

排列是把 n 个元素排成一列，$n!$ 种排法对应 $n!$ 个候选。基本移动是交换两个位置上的元素。图 15.2把三种移动画在一起。

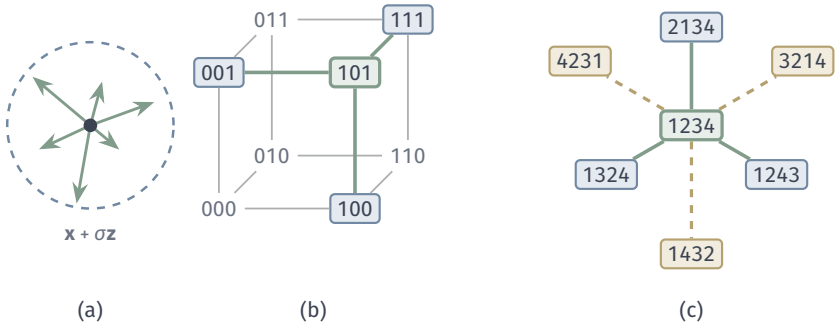


图 15.2 三种候选上的移动，绿色表示当前候选及其一步移动。(a) 连续参数的扰动，虚线圆表示尺度 σ 的量级。(b) 三位二进制串构成立方体，蓝框是 101 的三个翻位邻居。(c) 排列 1234 的邻居，蓝框是相邻交换，黄框和虚线是不相邻位置的交换。

把“一步能到达的候选”记为**邻域**（neighborhood）$\boldsymbol{N}(\boldsymbol{x}) \subset \boldsymbol{C}$。邻域决定了一张图：候选是顶点，$\boldsymbol{y} \in \boldsymbol{N}(\boldsymbol{x})$ 就连一条边。局部低谷、爬坡路径都是相对这张图而言的，换一个邻域，低谷可能就不存在了。

编码要保留原问题的含义 候选的表示必须让移动后的结果仍然有意义。例如选择问题用 0–1 串，第 i 位表示第 i 件物品选或不选，翻一位正是“多拿或少拿一件”，含义清楚。

把一个 0 到 15 的整数写成四位二进制，翻最高位会使整数变化 8，翻最低位只变化 1。从 $7 = 0111$ 到相邻的 $8 = 1000$ 要同时翻四位，数值上的近邻在编码上反而很远。这种表示下，翻位邻域与“数值接近”不是一回事，邻域的设计要先问清楚这一点。

相邻交换与任意交换 用同一个问题比较两种邻域。平面上五个城市 $A(1,4)$、$B(2,4)$、$C(3,5)$、$D(2,5)$、$E(5,0)$，距离取坐标差绝对值之和，一个访问顺序的代价是相邻两城距离之和，不返回起点。当前顺序 $ABECD$ 的代价是

$$1 + 7 + 7 + 1 = 16.$$

这条路线在中途绕向远处的 E，然后折返，见图 15.3(a)。

相邻交换只调换相邻的两个位置，$ABECD$ 的四个邻居的代价是

$$BAECD：17,\quad AEBCD：18,\quad ABCED：18,\quad ABEDC：17.$$

都比 16 高，所以 $ABECD$ 是相邻交换下的局部低谷。

任意交换允许调换任何两个位置。交换 E 和 D 得到 $ABDCE$，代价是

$$1+1+1+7=10,$$

一步就到了五城问题的最优解，见图 15.3(b)。

相邻交换也能到达最优解，只是要先爬坡：$ABECD \to ABCED \to ABCDE \to ABDCE$，代价依次是

$$16 \to 18 \to 12 \to 10.$$

这条路要先翻过高度为 2 的坎。同一对候选，在一种邻域下一步可达，在另一种邻域下隔着障碍。

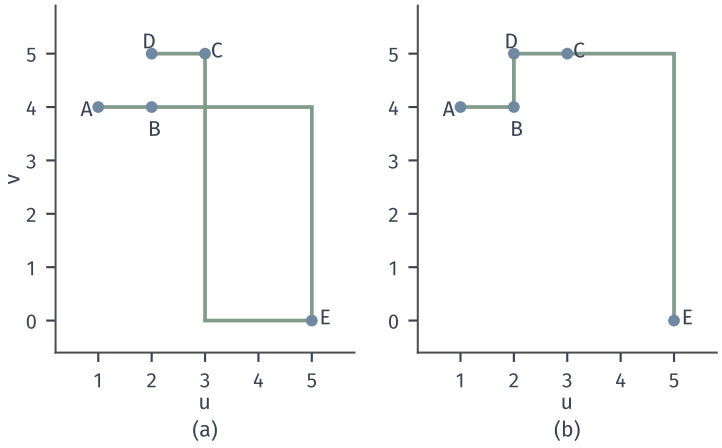


图 15.3 五城访问顺序，绿线按坐标差绝对值之和的路线画出，u, v 是城市的横纵坐标。(a) 顺序 $ABECD$，长度 16，四种相邻交换都使长度变大。(b) 交换不相邻的 E 和 D 得到 $ABDCE$，长度 10。

邻域并不是越大越好。五个位置时，相邻交换的邻居有 4 个，任意交换的有 10 个。任意两个排列之间，相邻交换至多需要 10 步，任意交换至多需要 4 步。

表 15.1列出这个比较。邻域大，一步能跳得远，图的直径小；代价是随机抽一个邻居时，抽到好邻居的机会被稀释，要穷举全部邻居时评价次数也更多。邻域的大小和移动尺度是算法设计中要专门决定的量，它与后面的接受规则彼此独立。

15.1 搜索问题
15.1.1 搜索空间
15.1.2 搜索状态
15.2 模拟退火
15.3 演化策略
15.4 遗传算法
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

表 15.1 n 个元素的排列上两种交换邻域的比较，括号内是 $n=5$ 的值。

	相邻交换	任意交换
邻居个数	$n-1$（4）	$n(n-1)/2$（10）
任两排列间的最多步数	$n(n-1)/2$（10）	$n-1$（4）
是否能到达所有排列	能	能
一次移动改变的位置关系	小	可能很大

15.1.2 搜索状态

邻域回答“能走到哪里”。接下来的问题是：两次评价之间，算法手里究竟保存着什么？后面四类方法在这一点上差别最大，先把它们放在一起对比。

四种需要区分的对象 **当前候选**是算法下一步移动的出发点，模拟退火就只维护这一个点。**群体成员**是同时维护的多个候选，遗传算法和粒子群属于这一类，粒子还各自带着速度。

搜索分布参数不是候选，而是描述“下一批候选从哪里抽”的量，例如高斯分布的中心和协方差。中心 $\boldsymbol{m}$ 本身可能从未被评价过。**历史最好记录**是式 (15.5)定义的结果，它只被写入，不参与移动，除非某种算法特意使用它。

图 15.4画出前三种状态，空心圆是各自的历史最好记录。表 15.2比较它们带着什么信息。

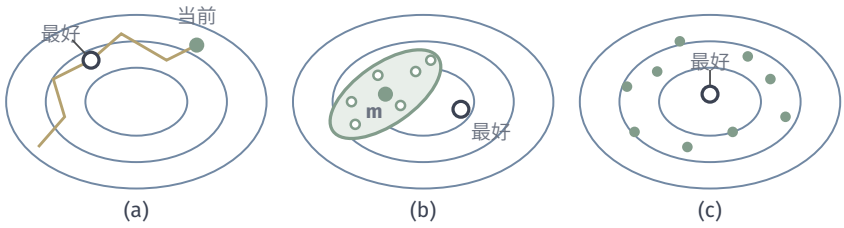


图 15.4 三种搜索状态，蓝线是目标等高线，空心圆是单独保存的历史最好记录。(a) 单个当前候选（绿点）及其走过的路径（黄线），当前点可以比历史最好差。(b) 搜索分布，绿点是中心 $\boldsymbol{m}$，椭圆是分布的形状，空心小圆是抽到的后代，最好记录可能在椭圆外。(c) 候选群体。

15.1 搜索问题
15.2 模拟退火
15.2.1 提议与接受
15.2.2 温度与能垒
15.2.3 有限预算的退火
15.3 演化策略
15.4 遗传算法
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

表 15.2 搜索状态承载的信息。

状态	记住什么	下一批候选从哪里来
单个候选	一个点	这个点的邻域
搜索分布	中心、尺度、形状	从分布抽样
候选群体	多个点及其评价	成员的组合与变动

为什么要单独保存最好记录 后面会看到，模拟退火有时接受更差的候选，整代替换的算法会把上一代全部丢弃。当前状态的代价因此可以上升，算法停止时手里的当前点可能比中途见过的某个点差很多。

保存记录的代价只是多存一个点。它不影响搜索的走向，却保证无噪声时交出的结果不差于任何已见的可行候选。所以无论采用什么算法，完整流程都要写上这一步。

与函数值方向估计的分工 第 14章也只用函数值：在当前点附近做差分或随机方向试探，组成梯度的估计 $\hat{\boldsymbol{g}}^{(t)}$，再走一步：

$$\boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} - \alpha^{(t)}\hat{\boldsymbol{g}}^{(t)}.$$

它的主要对象是一个点和一个方向，分析用的是局部光滑性。

本章的主要对象是候选和选择，通常只用比较结果，也不要求 f 有导数，排列、开关这样的离散候选上根本谈不上方向。两者也有重合之处：后面第 15.3节的高斯搜索分布，其均值的更新量可以看成平滑目标的梯度估计，这样的方法同时属于两种视角。

15.2 模拟退火

上一节的双谷问题里，只走向更低邻居的规则停在 $x = 2$。这就需要回答：只维护一个状态，怎样让它有机会翻过障碍，又不至于一直乱走？**模拟退火**（simulated annealing，SA）的回答是：偶尔接受更差的候选，并让这种“偶尔”随时间变少。

用下山来想。一个人站在低谷里，四周都是上坡。如果他绝不上坡，就永远出不去；如果他毫不在乎坡度，就只是在地图上乱逛。合理的做法是：小坡常常愿意爬，大坡很少愿意爬，而且越到后面越不愿意爬。控制这份“愿意”的量就是温度。这个比喻到此为止：人站在山上看得到四周的坡，算法只知道它提议的那一点的代价。

15.1 搜索问题
15.2 模拟退火
15.2.1 提议与接受
15.2.2 温度与能垒
15.2.3 有限预算的退火
15.3 演化策略
15.4 遗传算法
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

15.2.1 提议与接受

一步退火由提议和接受组成。这一小节的问题是：接受规则应当怎样写，固定温度下它长期会把状态带到哪里？

主要思想 一步分两半。先**提议**：从当前状态 $\boldsymbol{x}$ 按分布 $q(\boldsymbol{x},\cdot)$ 抽一个候选 $\boldsymbol{y}$。这里设提议是对称的，即对任意 $\boldsymbol{x},\boldsymbol{y}$，有 $q(\boldsymbol{x},\boldsymbol{y})=q(\boldsymbol{y},\boldsymbol{x})$。

再**接受**：给定温度 $T>0$，计算

$$a_T(\boldsymbol{x},\boldsymbol{y})=\min\Big\{1,\ \exp\Big(-\frac{f(\boldsymbol{y})-f(\boldsymbol{x})}{T}\Big)\Big\}, \tag{15.6}$$

以概率 $a_T(\boldsymbol{x},\boldsymbol{y})$ 移动到 $\boldsymbol{y}$，否则留在 $\boldsymbol{x}$。

下降或持平的提议一定被接受，上升的提议按上升量指数衰减的概率被接受。图 15.5(a) 画出这个函数：T 大时曲线平缓，上坡也常被接受；$T\to 0$ 时规则退回到只接受不上升的移动。

在双谷代价 (15.2)上取 $T=2$，算一次下降和一次上升。从 $x=3$ 提议 $y=2$，代价差是 -2，接受概率为 1。反过来，从 $x=2$ 提议 $y=3$，代价差是 $+2$，接受概率为

$$\exp(-2/2)=\mathrm{e}^{-1}\approx 0.368.$$

上坡的代价差要除以温度才有意义。把 f 整体乘以 10，同时把 T 乘以 10，接受概率完全不变。所以温度的单位就是代价的单位，选温度必须看代价的尺度。

固定温度下的长期分布 温度固定时，状态序列是一个马尔可夫链：下一个状态的分布只取决于当前状态。对 $\boldsymbol{y}\neq\boldsymbol{x}$，一步转移的概率是

$$P_T(\boldsymbol{x},\boldsymbol{y})=q(\boldsymbol{x},\boldsymbol{y})\,a_T(\boldsymbol{x},\boldsymbol{y}), \tag{15.7}$$

被拒绝的概率加到 $P_T(\boldsymbol{x},\boldsymbol{x})$ 上。这个规则与下面的Gibbs 分布（Gibbs distribution）紧密相关。在有限状态集合 $\boldsymbol{C}$ 上定义

$$\pi_T(\boldsymbol{x})=\frac{\exp(-f(\boldsymbol{x})/T)}{Z_T},\qquad Z_T=\sum_{\boldsymbol{u}\in\boldsymbol{C}}\exp(-f(\boldsymbol{u})/T). \tag{15.8}$$

代价越低，权重越大。

定理 15.1 细致平衡 设 $\boldsymbol{C}$ 有限，q 对称，$T>0$。则对任意 $\boldsymbol{x},\boldsymbol{y}\in\boldsymbol{C}$，

$$\pi_T(\boldsymbol{x})P_T(\boldsymbol{x},\boldsymbol{y})=\pi_T(\boldsymbol{y})P_T(\boldsymbol{y},\boldsymbol{x}), \tag{15.9}$$

因此 π_T 是转移矩阵 $\boldsymbol{P}_T$ 的平稳分布。

证明 $\boldsymbol{x}=\boldsymbol{y}$ 时两边相同。设 $\boldsymbol{x}\neq\boldsymbol{y}$，不妨设 $f(\boldsymbol{y})\geq f(\boldsymbol{x})$，否则交换两者的名字。这时从 $\boldsymbol{y}$ 到 $\boldsymbol{x}$ 是下降，$a_T(\boldsymbol{y},\boldsymbol{x})=1$，于是右边是

$$\pi_T(\boldsymbol{y})P_T(\boldsymbol{y},\boldsymbol{x})=\frac{\exp(-f(\boldsymbol{y})/T)}{Z_T}\,q(\boldsymbol{y},\boldsymbol{x}).$$

从 $\boldsymbol{x}$ 到 $\boldsymbol{y}$ 是上升，代入式 (15.6)，左边是

$$\begin{aligned}\pi_T(\boldsymbol{x})P_T(\boldsymbol{x},\boldsymbol{y})&=\frac{\exp(-f(\boldsymbol{x})/T)}{Z_T}\,q(\boldsymbol{x},\boldsymbol{y})\exp\Big(-\frac{f(\boldsymbol{y})-f(\boldsymbol{x})}{T}\Big)\\&=\frac{\exp(-f(\boldsymbol{y})/T)}{Z_T}\,q(\boldsymbol{x},\boldsymbol{y}).\end{aligned}$$

由 q 的对称性，两边相等。

对式 (15.9)关于 $\boldsymbol{x}$ 求和，转移概率对第二个变量求和为 1，于是

$$\sum_{\boldsymbol{x}}\pi_T(\boldsymbol{x})P_T(\boldsymbol{x},\boldsymbol{y})=\pi_T(\boldsymbol{y}),$$

这正是平稳性。 ■

平稳分布存在不等于状态序列一定趋向它。若提议图连通，并且链不被周期卡住（例如某些状态有正的停留概率），状态的分布才从任何起点收敛到 π_T。这一收敛结论的证明用到有限马尔可夫链的基本定理，可参考卷九第 3 章“离散时间随机过程”。

图 15.5(b) 是双谷问题的 π_T。$T=2$ 时六号状态的概率约为 0.348，二号状态约为 0.211，高处的状态也有不小的份额。$T=0.5$ 时六号状态约为 0.850，二号状态约为 0.115。

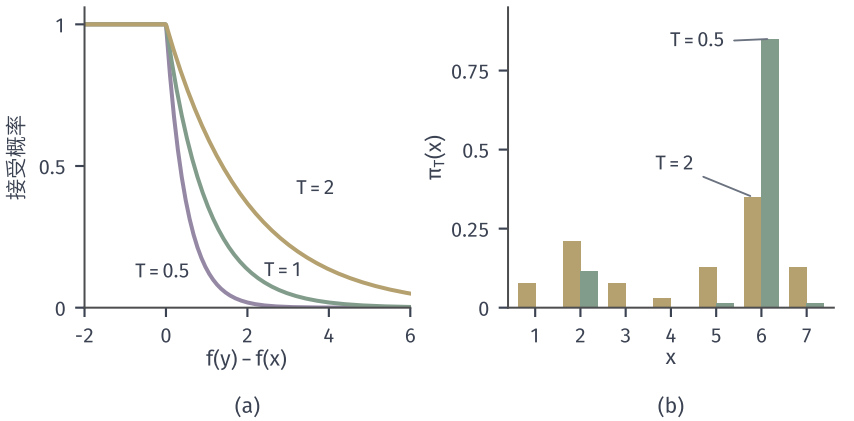


图 15.5 接受规则与长期分布。(a) 接受概率 (15.6)作为代价差的函数。(b) 双谷代价 (15.2)的 Gibbs 分布，黄色柱为 $T=2$，绿色柱为 $T=0.5$，温度越低，概率越集中在代价低的状态。

温度趋于零时，π_T 集中到全局最小点上。设 $\boldsymbol{S}^\star$ 是全局最小点的集合，对任一非全局最小点 $\boldsymbol{x}$ 和 $\boldsymbol{x}^\star \in \boldsymbol{S}^\star$，比值

$$\frac{\pi_T(\boldsymbol{x})}{\pi_T(\boldsymbol{x}^\star)} = \exp\!\Big(-\frac{f(\boldsymbol{x}) - f^\star}{T}\Big) \to 0 \qquad (T \to 0^+).$$

状态有限，所以 $\pi_T(\boldsymbol{S}^\star) \to 1$。这就是降温的动机：低温时的长期分布几乎全在最优解上。

问题在于“长期”。温度越低，翻越障碍越慢，走到长期分布所需的时间越长。第 15.2.2节把这件事说清楚。

提议不对称会怎样 证明的最后一步用了 q 的对称性。提议不对称时，平衡关系就不再成立。看两个状态、代价相同的情形，$\pi_T = (1/2, 1/2)$。

设从状态 1 总是提议 2，而从状态 2 以 $1/2$ 的概率提议 1，以 $1/2$ 的概率提议自身。代价相同，接受概率都是 1。两状态的平稳条件是 $\pi(1)\cdot 1 = \pi(2)\cdot \frac{1}{2}$，于是

$$\pi = \Big(\frac{1}{3}, \frac{2}{3}\Big) \neq \Big(\frac{1}{2}, \frac{1}{2}\Big).$$

要恢复目标分布，需要把提议比例放进接受概率：

$$a_T(\boldsymbol{x}, \boldsymbol{y}) = \min\Big\{1,\ \exp\!\Big(-\frac{f(\boldsymbol{y}) - f(\boldsymbol{x})}{T}\Big)\frac{q(\boldsymbol{y}, \boldsymbol{x})}{q(\boldsymbol{x}, \boldsymbol{y})}\Big\}. \tag{15.10}$$

上面的例子里，$a(1,2) = 1/2$，$a(2,1) = 1$，两个方向的流量都是 $\pi(\cdot)\cdot\frac{1}{2}$，$(1/2, 1/2)$ 重新平稳。这个修正的一般讨论可参考卷七第 14 章“随机采样与积分计算”。

变量 下面在双谷代价上手算几步。要维护的量是：

- $x^{(t)}$：当前状态，$f(x^{(t)})$ 是它的代价；
- $T^{(t)} > 0$：第 t 步的温度；
- x_{best}，f_{best}：历史最好记录。

初始化 选起点和初始温度，把起点记为最好记录。例中从局部低谷出发，温度每步乘以 0.9：

$$x^{(0)} = 2, \qquad T^{(0)} = 2, \qquad T^{(t)} = 2 \times 0.9^{t}, \qquad f_{\text{best}} = 1.$$

提议是等概率选左或右，超出范围时提议留在原地。

每轮更新 第 t 轮依次执行以下步骤，直到用完预算。下面每一轮的提议方向和均匀随机数 u 都是事先列好的，以便逐步核对。

1. 从 $q(x^{(t)}, \cdot)$ 抽候选 y，评价 $f(y)$。例中第 0 轮提议 $y = 1$，$f(y) = 3$。
2. 由式 (15.6)计算接受概率。例中第 0 轮代价差是 2，$T^{(0)} = 2$，接受概率为 0.368。
3. 抽 $u \sim \mathrm{U}(0,1)$，若 $u < a$，令 $x^{(t+1)} = y$，否则 $x^{(t+1)} = x^{(t)}$。例中第 0 轮 $u = 0.71$，拒绝，状态仍为 2。
4. 若 y 可行且 $f(y) < f_{\text{best}}$，更新最好记录。例中第 0 轮不更新。

表 15.3列出前六轮。第 1、2 轮两次上坡都被接受，状态爬到垒顶 $x = 4$，代价是 5，比记录差很多；接着第 3、4 轮是下坡，必然接受，第 4 轮到达 $x = 6$，最好记录更新为 0。第 5 轮提议上坡到 $x = 7$，被拒绝。

表 15.3 双谷代价上的前六轮，a 是接受概率，u 是列好的随机数。

t	$T^{(t)}$	$x^{(t)}$	y	$f(y) - f(x^{(t)})$	a	u	f_{best}
0	2.000	2	1	+2	0.368	0.71	1
1	1.800	2	3	+2	0.329	0.25	1
2	1.620	3	4	+2	0.291	0.18	1
3	1.458	4	5	−3	1	—	1
4	1.312	5	6	−2	1	—	0
5	1.181	6	7	+2	0.184	0.62	0

最终得到 $x_{\text{best}} = 6$，$f_{\text{best}} = 0$。这是特意挑选的一条幸运路径，连续爬坡两次的概率并不大，真实的成功机会要由下面的整体计算回答。

这个例子也说明了两条轨迹的区别：当前状态在第 2 轮爬到了代价 5，比出发时差得多，而记录始终不变差。

15.1 搜索问题
15.2 模拟退火
15.2.1 提议与接受
15.2.2 温度与能垒
15.2.3 有限预算的退火
15.3 演化策略
15.4 遗传算法
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

15.2.2 温度与能垒

温度要降到多慢，才能保证最终找到全局最小？这一小节回答这个问题，也要说明这个答案能用到什么程度。

能垒 在双谷问题中，从 $x=2$ 到代价更低的 $x=6$，必须经过 $x=4$。路径上的最高代价是 5，比出发点高 4。这个高度刻画了离开这个低谷的困难。

一般地，给定提议图和一个不是全局最小的局部低谷 $\boldsymbol{x}$，考虑从 $\boldsymbol{x}$ 到所有代价严格更低的状态的路径。路径 $\boldsymbol{x}=\boldsymbol{w}_0,\boldsymbol{w}_1,\dots,\boldsymbol{w}_k$ 沿提议图的边走，$f(\boldsymbol{w}_k)<f(\boldsymbol{x})$。定义**能垒**（energy barrier）为

$$d(\boldsymbol{x})=\min_{\text{路径}}\ \max_{0\le j\le k}\big(f(\boldsymbol{w}_j)-f(\boldsymbol{x})\big), \tag{15.11}$$

即在所有出路中，选最省力的一条，所要爬的最大高度。全部非全局低谷的能垒中最大的一个记为 $d^\star$。

双谷问题只有一个非全局低谷 $x=2$。向左走不通，向右必须经过 $x=4$，所以

$$d(2)=5-1=4,\qquad d^\star=4.$$

图 15.6标出这个高度。注意能垒不等于单步的代价差：$x=2$ 的邻居只比它高 2，真正要爬的是连续两步累计的 4。

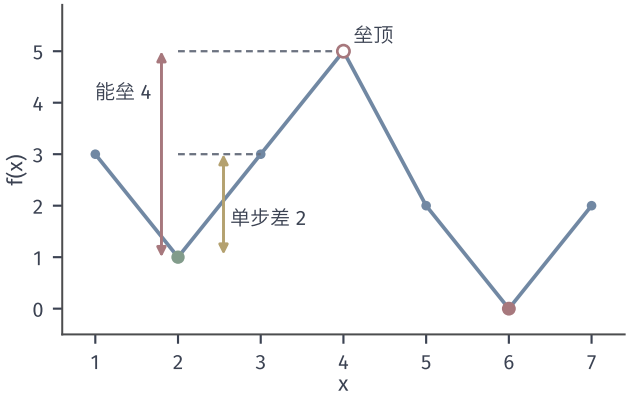


图 15.6 双谷代价的能垒。绿点是非全局低谷 $x=2$，空心红点是通往全局最小（红色实心点）必经的垒顶 $x=4$。红色双箭头是能垒 $d(2)=4$，黄色双箭头是一步上坡的代价差 2。

对数降温的条件 先看量级。温度为 T 时，翻过能垒 d 的那条路径大约要付出 $\exp(-d/T)$ 的概率，所以大约要等 $\exp(d/T)$ 步才能出去一次。$T=1$ 时 $\mathrm{e}^4\approx 55$ 步，$T=0.25$ 时已经约有 8.9×10^6 步。

要让出去的机会永远不会用完，把每一步的逃逸机会加起来应当发散：

$$\sum_{t} \exp(-d^\star / T^{(t)}) = \infty.$$

取**对数降温**（logarithmic cooling）$T^{(t)} = c/\log(t+2)$，有 $\exp(-d^\star/T^{(t)}) = (t+2)^{-d^\star/c}$，这个级数在 $c \ge d^\star$ 时发散，在 $c < d^\star$ 时收敛。这就是下面定理的来历。

定理 15.2　对数降温下的全局收敛　设 $\boldsymbol{C}$ 是有限集，提议 q 对称，提议图连通，链允许原地停留。若温度取

$$T^{(t)} = \frac{c}{\log(t+2)}, \qquad c \ge d^\star, \tag{15.12}$$

则从任何起点出发，

$$\lim_{t\to\infty} \mathbb{P}\big(\boldsymbol{x}^{(t)} \in \boldsymbol{S}^\star\big) = 1. \tag{15.13}$$

反之，若 $0 < c < d^\star$，则存在起点使这个极限不为 1。

这一结论由 Hajek 于 1988 年给出，证明需要按代价高度逐层分析链在谷之间的转移，篇幅较长，这里不给出。下面的引理证明其中反方向的一个特殊情形，它能说明温度降得太快时发生了什么。

引理 15.3　降温过快时可能永远停住　设 $\boldsymbol{x}$ 的所有邻居的代价都至少比 $f(\boldsymbol{x})$ 高 $h > 0$。若 $T^{(t)} = c/\log(t+2)$，$0 < c < h$，则从 $\boldsymbol{x}$ 出发，状态永远不离开 $\boldsymbol{x}$ 的概率为正。

证明　第 t 步离开 $\boldsymbol{x}$，必须接受一次上升量不小于 h 的提议，其概率不超过

$$\exp(-h/T^{(t)}) = (t+2)^{-h/c}.$$

记 $\beta = h/c > 1$。在前面各步都没有离开的条件下，第 t 步留下的概率至少是 $1-(t+2)^{-\beta}$，把这些条件概率连乘，永远不离开的概率至少是

$$\prod_{t=0}^{\infty} \big(1 - (t+2)^{-\beta}\big).$$

由 $\beta > 1$，$\sum_t (t+2)^{-\beta} < \infty$，并且每个因子都大于 0，所以这个无穷乘积大于 0。 ∎

用双谷问题具体算一次。$x=2$ 的两个邻居都比它高 2，所以 $h=2$。取 $c=1$，提议左右各 $1/2$，接受概率都是 $(t+2)^{-2}$，第 t 步离开的概率恰为 $(t+2)^{-2}$。于是永远留在 $x=2$ 的概率是

$$\prod_{k=2}^{\infty}\Big(1-\frac{1}{k^2}\Big)=\lim_{K\to\infty}\frac{K+1}{2K}=\frac{1}{2}.$$

部分积由 $(1-1/k^2)=\frac{(k-1)(k+1)}{k\cdot k}$ 逐项相消得到。这个算法从 $x=2$ 出发，有一半的概率从第一步到无穷都不动。

图 15.7用转移矩阵的精确乘积算出从 $x=2$ 出发时 $x^{(t)}=6$ 的概率，不含抽样误差。$c=1$ 和 $c=2$ 都低于 $d^\star=4$，概率很快走平，到 $t=2\times10^6$ 时分别约为 0.007 和 0.077。$c=4$ 和 $c=8$ 满足条件，概率持续上升，但到 $t=2\times10^6$ 时也只有约 0.895 和 0.816。

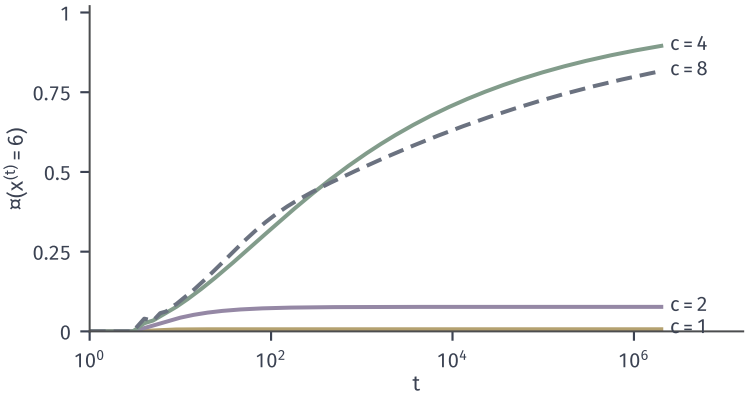


图 15.7　对数降温 (15.12)下从 $x=2$ 出发时第 t 步处于全局最小的概率，由双谷链的转移矩阵逐步相乘精确算出。$d^\star=4$，黄、紫两线的 c 小于 $d^\star$，绿线取 $c=4$，灰色虚线取 $c=8$。横轴为对数刻度。

定理能保证什么　这个定理的每个条件都要读准。常数 c 要覆盖能垒 $d^\star$，而 $d^\star$ 事先通常不知道。定理只对有限状态、对称连通提议成立，提议不对称或被修复过时，要重新核对。

结论是概率的极限，不是“多少步之内一定找到”。七个状态的问题，穷举只要 7 次评价，满足条件的对数降温用了两百万步仍有约一成的概率不在最优解上。c 取得更大也不是更好：$c=8$ 在这个时间范围内反而不如 $c=4$。

定理也不能换成任意的降温规则。按固定比例降温，$T^{(t)}=T^{(0)}\rho^t$，$0<\rho<1$，这时 $\sum_t \exp(-d^\star/T^{(t)})<\infty$，定理的发散条件不满足。下一小节会看到，实际常用的正是这种规则；它能用，但不能借用上面的极限结论。

15.1 搜索问题
15.2 模拟退火
15.2.1 提议与接受
15.2.2 温度与能垒
15.2.3 有限预算的退火
15.3 演化策略
15.4 遗传算法
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

15.2.3 有限预算的退火

实际运行时，预算 B 是给定的。这一小节讨论：在 B 次评价之内，温度应当怎样安排，完整流程要包含什么？

三种安排 第一种是**固定温度**，全程 T 不变，一共 B 步。第二种是**几何降温**（geometric cooling），每隔若干步把温度乘以比例 $\rho \in (0,1)$：

$$T^{[\ell]} = T^{[0]} \rho^{\ell}, \qquad \ell = 0, 1, \dots, K-1. \tag{15.14}$$

这里 ℓ 是温度的层号，用方括号上标与迭代步区分。第三种是**分段降温**，事先列出几个温度，每个温度跑一段。

一层温度上尝试 M 次提议，共 K 层，那么一次提议就是一次评价，加上起点的一次，总评价次数是

$$B = 1 + KM. \tag{15.15}$$

预算一定时，层数多则每层短，ρ 接近 1 时降得慢。预算增加时应当把降温拉长，而不是在同样的降温后面接一段低温下的原地踏步。

温度的尺度 上一小节说过，温度要和代价尺度配套。常用办法是用初始的上坡量定温度。若典型的上坡量是 $\bar{\Delta}$，希望初始接受概率是 χ_0，那么由 $\exp(-\bar{\Delta}/T^{[0]}) = \chi_0$，得到

$$T^{[0]} = \frac{\bar{\Delta}}{\ln(1/\chi_0)}. \tag{15.16}$$

双谷问题的上坡量多为 2，取 $\chi_0 = 0.6$，得

$$T^{[0]} = \frac{2}{\ln(1/0.6)} \approx 3.9,$$

可取 $T^{[0]} = 4$。结束温度取到上坡几乎不被接受，比如 0.1，这时上坡量 2 的接受概率约为 2×10^{-9}。$\bar{\Delta}$ 可以先随机试若干对邻居来估计，这些试探也要记入评价次数。

提议的尺度是另一个独立的量。温度决定“接不接受”，邻域大小决定“提议走多远”。把温度调高，并不会让提议跳得更远。

预算内的结果 图 15.8在双谷链上比较四种安排，每种安排都按预算 B 重新拉伸，并用吸收链精确计算“前 B 步内到过 $x = 6$”的概率。几何降温从 4 到 0.1；分段降温依次用 $4, 2, 1, 0.5, 0.25$；固定温度取 $T = 1$；对数降温取 $c = 4$。

预算为 10^4 时，几何、分段和固定温度三种安排都几乎必然到过全局最小，只有对数降温的概率约为 0.80。对数降温在小预算时略占优势，到了大预算反而落后：它在高温停留很短，后面长时间逗留在约 0.5 的低温，翻过能垒的机会稀少。

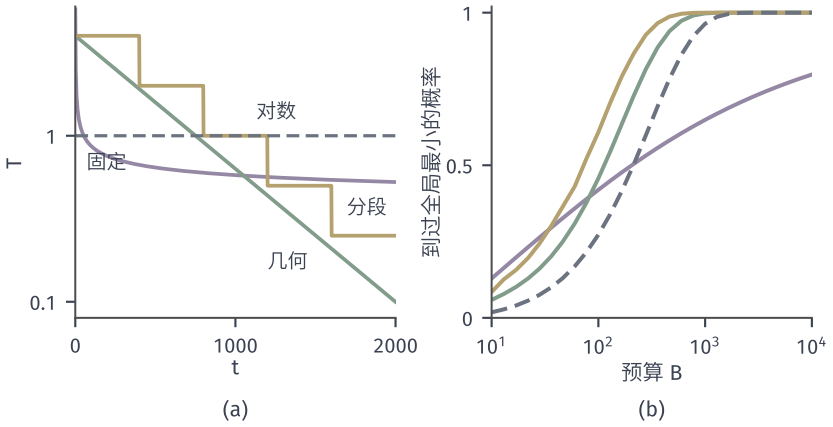


图 15.8　双谷链上的降温安排比较。紫线为对数降温 $c = 4$，绿线为几何降温 $(4 \to 0.1)$，黄线为分段降温，灰色虚线为固定温度 $T = 1$。(a) 预算 $B = 2000$ 时的温度，纵轴对数刻度。(b) 预算 B 之内到过全局最小的精确概率。

这里要分清两个量。“到过”对应最好记录；“结束时停在那里”对应当前状态。预算 10^4 时，结束时处于 $x = 6$ 的概率，几何降温约为 0.79，分段降温约为 0.75，对数降温约为 0.71，固定温度 $T = 1$ 约为 0.57。固定温度下最好记录几乎一定拿到最优，当前状态却只有 $\pi_1(6) \approx 0.57$。

这也回答了为什么最好记录必须写进流程：不写它，固定温度下交出的当前状态有四成多的概率不是最优解。

完整流程　把前面的决定合起来，一次带重启的退火这样组织。先确定预算 B，试探代价尺度，由式 (15.16)定 $T^{[0]}$，选结束温度、比例 ρ 和每层步数 M，使总评价满足预算。

然后运行提议、接受和记录更新，每完成一层就降温。一次退火结束后，若预算还有剩余，就从新的起点重新开始，保留全局的最好记录。若单次运行成功的概率是 p，独立重启 K 次，至少成功一次的概率是

$$1 - (1 - p)^K. \tag{15.17}$$

例如 $p = 0.2$，$K = 5$，得到 $1 - 0.8^5 \approx 0.67$。把预算切成几次短运行，单次的 p 会变小，所以切多少份要依问题试验确定。

图 15.9是二维 Rastrigin 函数上一次预算为 3000 的运行。高温阶段当前点在各个小坑之间跳动，代价可以高到几十；温度降低后渐渐落入一个小

15.1 搜索问题
15.2 模拟退火
15.3 演化策略
15.3.1 变异与重组
15.3.2 亲代选择
15.3.3 协方差适应
15.3.4 步长适应
15.3.5 自然演化策略（补充）
15.4 遗传算法
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

坑，后期几乎不再接受上坡。这次运行的最好记录为 $(-0.004, 0.034)$，代价约为 0.23。

这是这一次运行得到的结果，换一个种子结果就可能不同。在有限预算下，这样的方法要按运行结果的分布评价，不能因为存在对数降温的极限定理，就说它“能收敛到全局最优”。第 15.8节回到如何评价的问题。

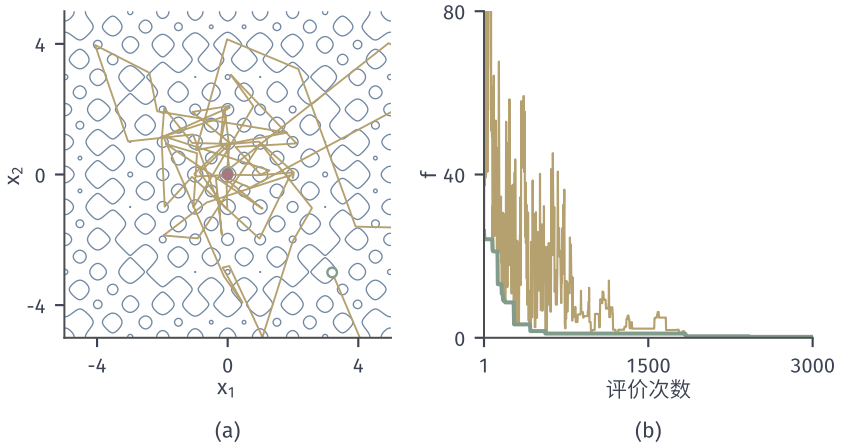


图 15.9 二维 Rastrigin 函数 (15.3)上的一次模拟退火，高斯提议 $\sigma = 0.8$，温度从 25 几何下降到 0.05，$B = 3000$，种子固定。(a) 蓝线是等高线，黄线是当前状态的路径（每隔 18 步取一点），空心圆是起点，绿点是最好记录，红点是全局最小点。(b) 黄线是当前状态的代价，绿线是最好记录的代价。

15.3 演化策略

模拟退火只有一个状态，提议的形状事先给定。连续变量上还有一种选择：不维护候选，而维护一个“下一批候选从哪里抽”的分布，并让评价结果来修改这个分布。怎样根据一批候选的好坏，调整分布的中心、尺度和形状？这类方法称为**演化策略**（evolution strategy，ES）。

一代的流程是：抽出若干候选（称为**后代**，offspring），评价，选出较好的（称为**亲代**，parents），再由亲代决定下一代的分布。这里的“亲代”“后代”只是名称，所有内容都由下面的公式定义。本节用 μ 表示亲代个数，λ 表示后代个数，两者都是正整数，不再表示强凸常数和乘子。

15.3.1 变异与重组

后代从亲代而来。这一小节的问题是：单个后代怎样产生，有多个亲代时又怎样利用它们？

高斯变异 从亲代 $\boldsymbol{x}$ 产生后代的基本方式是加一个高斯扰动：

$$\boldsymbol{y} = \boldsymbol{x} + \sigma \boldsymbol{z}, \qquad \boldsymbol{z} \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{I}), \tag{15.18}$$

称为**高斯变异**（Gaussian mutation）。步长 $\sigma > 0$ 控制扰动的整体尺度，各向同性指的是所有方向的扰动幅度相同。

用全卷的二次例子 $f(\boldsymbol{x}) = \frac{1}{2}(x_1^2 + 9x_2^2)$ 手算一次。在 $\boldsymbol{x} = (9, 1)$ 处，$f = 45$。取 $\sigma = 1$，抽到 $\boldsymbol{z} = (-0.8, -0.5)$，后代是 $(8.2, 0.5)$，代价为

$$\frac{1}{2}(67.24 + 2.25) \approx 34.75,$$

比亲代好，留下。抽到 $\boldsymbol{z} = (-0.2, 0.9)$ 时，后代是 $(8.8, 1.9)$，代价约为 54.97，变差，丢弃。这样只保留变好的结果，就是最简单的 $(1 + 1)$ 策略，名字的含义下一小节解释。

各向同性的局限 这个目标在 x_2 方向比 x_1 方向陡 9 倍。图 15.10(a) 在 $(9, 1)$ 周围取 $\sigma = 2$ 抽 60 个后代，绿点代价下降，红圈代价上升。圆形的云团和拉长的等高线不匹配：往 x_2 方向稍远一点就越出了等高线。

图 15.10(b) 用 8×10^5 个样本估计改善的概率。σ 趋于零时，等高线局部接近直线，改善概率趋于 $1/2$；σ 增大，各向同性的抽样在 $\sigma \approx 2$ 时约为 0.31，而沿等高线拉伸的抽样（两个方向的标准差比为 3 ： 1，面积相同）仍约有 0.42。

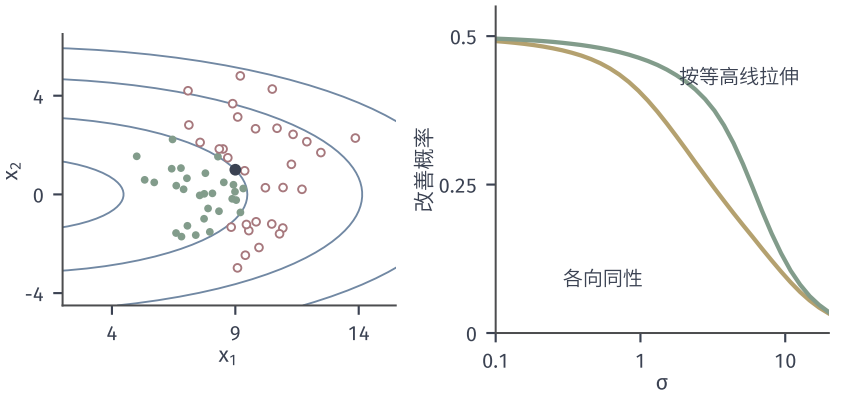


图 15.10 $f = \frac{1}{2}(x_1^2 + 9x_2^2)$ 上的变异，亲代在 $(9, 1)$。(a) 蓝线是等高线，深色点是亲代，$\sigma = 2$ 的各向同性后代中绿点改善、红圈变差。(b) 改善概率随 σ 的变化，黄线为各向同性抽样，绿线的两个坐标标准差分别为 $\sqrt{3}\sigma$ 和 $\sigma/\sqrt{3}$，由固定种子抽样估计。

所以固定的圆形变异有两个问题：σ 要随进展变化，形状也应当贴合地形。后面两小节分别解决。

15.1 搜索问题
15.2 模拟退火
15.3 演化策略
15.3.1 变异与重组
15.3.2 亲代选择
15.3.3 协方差适应
15.3.4 步长适应
15.3.5 自然演化策略（补充）
15.4 遗传算法
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

多个亲代：选一个还是合成一个 有多个亲代时，有两种产生后代的方式。一种是每次选一个亲代，在它周围变异。另一种是先把亲代合成一个点，称为**重组**（recombination），再从这一点变异，比如取权重 $w_1 \geq \cdots \geq w_\mu > 0$，$\sum_i w_i = 1$，按代价从好到差排序，

$$\boldsymbol{m} = \sum_{i=1}^{\mu} w_i \boldsymbol{x}_{i:\lambda}, \tag{15.19}$$

下标 $i:\lambda$ 表示 λ 个后代中第 i 好的那个。

取两个亲代手算。$\boldsymbol{x}_{1:\lambda} = (7, -0.8)$ 的代价为 27.38，$\boldsymbol{x}_{2:\lambda} = (8, 0.6)$ 的代价为 33.62。权重取 $(3/4, 1/4)$，重组后得到

$$\boldsymbol{m} = \tfrac{3}{4}(7, -0.8) + \tfrac{1}{4}(8, 0.6) = (7.25, -0.45), \qquad f(\boldsymbol{m}) \approx 27.19.$$

重组点比两个亲代都好。

原因在于两个亲代沿 x_2 的偏差一正一负，平均后相互抵消，x_2 方向的代价又贵，于是抵消的好处很大。这是重组的一种效果：把各个亲代中互不相关的扰动平均掉，保留它们共有的移动。这也不是必然的结果，两个亲代偏差同号时重组就没有这个好处。

两类量 演化策略中有两类量要分开。一类是**待优化变量**，就是候选 $\boldsymbol{x}$ 本身，提交给 f 评价。另一类是**策略参数**，如 σ 和后面的协方差，它们决定怎样抽样，不提交给 f，却随代更新。

15.3.2 亲代选择

一代产生了 λ 个后代，下一代的亲代应从谁中选？这一小节比较两种规则，并说明它们各自能保证什么。

两种规则 $(\mu + \lambda)$ 策略从 μ 个旧亲代和 λ 个后代的并集中选出最好的 μ 个。(μ, λ) 策略只从 λ 个后代中选最好的 μ 个，旧亲代全部丢弃，因此要求 $\lambda \geq \mu$；$\lambda = \mu$ 时全部后代都入选，就没有选择了，实际要取 $\lambda > \mu$。

前面的 $(1 + 1)$ 就是一个亲代、一个后代，留下较好者的规则。

定理 15.4 保留亲代时最好值不增 设评价无噪声，亲代的代价是准确的。采用 $(\mu+\lambda)$ 选择时，记第 t 代亲代中的最小代价为 $f_{\min}^{(t)}$，则

$$f_{\min}^{(t+1)} \leq f_{\min}^{(t)}, \qquad t = 0, 1, \ldots. \tag{15.20}$$

> **证明** 第 t 代代价最小的亲代属于第 $t+1$ 代选择的并集。选择取并集中最好的 μ 个，所以并集的最小代价一定入选，而并集的最小代价不超过 $f_{\min}^{(t)}$。 ■

这个保证的边界 最好值不增不等于在进步，更不等于走向全局最优。把 $(1+1)$ 规则放在双谷问题上，变异只提议左右相邻的状态，从 $x=2$ 出发，两个邻居都更差，永远不会有后代入选。式 (15.20)成立，算法却永远停在 $f=1$。

高斯变异的支撑是全空间，任何点都有正的概率被抽到，但一次跳过很宽的障碍的概率随距离指数下降，这个正概率在有限预算下没有意义。旧亲代保留也可能拖累搜索：一个特别好的旧亲代长期占据位置，后代都比不过它，σ 的调整也因此失去依据。

两种规则的对比 图 15.11(a) 在二次目标上用固定的 $\sigma=0.5, \lambda=5, \mu=1$。保留亲代时曲线单调下降，到第 80 代代价约为 0.0026。整代替换时，每一代的亲代都是新的，到了尺度 σ 能分辨的精度后就在附近上下波动，第 80 代当前代价约为 0.10，只有其最好记录（虚线）约为 0.0016。

图 15.11(b) 换到二维 Rastrigin 函数，$\sigma=0.45$，40 次独立运行取中位数，起点 $(2,2)$，代价为 8。保留亲代时前期被小坑拦住，改进较慢；整代替换的最好记录（虚线）早期下降更快，因为当前点可以连续穿过小坑，但它的当前代价一直在 10 到 14 之间摆动，到 200 代时中位数约为 14，而保留亲代的中位数约为 0.39，整代替换的最好记录约为 0.85。

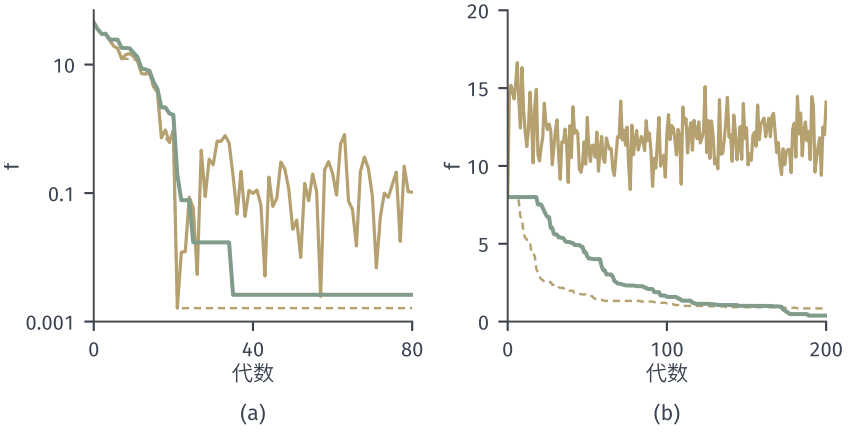


图 15.11 保留亲代（绿线）与整代替换（黄色实线为当前亲代的代价，黄色虚线为其历史最好）的对比，$\mu=1$，$\lambda=5$，σ 固定。(a)$f=\frac{1}{2}(x_1^2+9x_2^2)$，$\sigma=0.5$，一次运行，纵轴对数刻度。(b) 二维 Rastrigin 函数，$\sigma=0.45$，40 次运行的中位数，线性纵轴。

15.1 搜索问题
15.2 模拟退火
15.3 演化策略
15.3.1 变异与重组
15.3.2 亲代选择
15.3.3 协方差适应
15.3.4 步长适应
15.3.5 自然演化策略（补充）
15.4 遗传算法
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

表 15.4 两种亲代选择的对比。

	$(\mu+\lambda)$	(μ,λ)
旧亲代	与后代竞争	全部丢弃
无噪声时亲代最好值	不增	可能上升
是否需要单独保存最好记录	不必（已含在亲代中）	必须
好亲代长期占位	可能	不会

两种规则都需要配合下面的尺度和形状更新。选择只决定谁留下，走多远、朝哪个形状抽，还要靠策略参数。

15.3.3 协方差适应

圆形的抽样不贴合地形，这一小节的问题是：怎样让抽样分布的形状从评价结果中学出来？

主要思想 把圆形的扰动换成椭圆形，后代从下式抽取：

$$\boldsymbol{x}_i^{(t+1)} = \boldsymbol{m}^{(t)} + \sigma^{(t)}\boldsymbol{y}_i, \qquad \boldsymbol{y}_i \sim \mathcal{N}(\boldsymbol{0}, \boldsymbol{\Sigma}^{(t)}), \quad i = 1, \dots, \lambda. \tag{15.21}$$

这里 $\boldsymbol{m}^{(t)}$ 是分布的中心，$\sigma^{(t)}$ 是整体尺度，对称正定矩阵 $\boldsymbol{\Sigma}^{(t)}$ 描述形状。**协方差矩阵适应演化策略**（covariance matrix adaptation evolution strategy，CMA-ES）的思路是：让“抽到好后代的那些位移”的分布，成为下一代的抽样分布。

好后代位移的方向多次出现，就说明沿那个方向走有好处，下次沿这个方向多抽一些。可以这样对应：等高线是一条拉长的山谷，中心 $\boldsymbol{m}$ 是当前站立的位置，$\boldsymbol{\Sigma}$ 是下一次向四周探路时的步幅分配，把更多的步幅给谷底的走向。

具体的目标用旋转过的椭圆：

$$f(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x}, \qquad \boldsymbol{A} = \begin{bmatrix} 5 & -4 \\ -4 & 5 \end{bmatrix}. \tag{15.22}$$

$\boldsymbol{A}$ 的特征值是 1 和 9，对应的特征方向是 $(1,1)$ 和 $(1,-1)$，所以山谷沿 $(1,1)$ 方向。这种倾斜不能靠给两个坐标各设一个步长来表示，必须有非对角元。

更新分三步。第一步按评价排序，只用排序不用代价的数值，取前 μ 个 $\boldsymbol{y}_{i:\lambda}$。中心向它们的加权平均移动，权重 w_i 为正，和为 1：

$$\boldsymbol{y}_w = \sum_{i=1}^{\mu} w_i \boldsymbol{y}_{i:\lambda}, \qquad \boldsymbol{m}^{(t+1)} = \boldsymbol{m}^{(t)} + \sigma^{(t)}\boldsymbol{y}_w. \tag{15.23}$$

第二步累积一条路径。一代的 $\boldsymbol{y}_w$ 里有随机成分，但真实的好方向会在连续几代中重复出现。把连续几代的 $\boldsymbol{y}_w$ 累加起来，得到**演化路径**（evolution path）：

$$\boldsymbol{p}_c^{(t+1)} = (1-c_c)\boldsymbol{p}_c^{(t)} + \sqrt{c_c(2-c_c)\mu_w}\,\boldsymbol{y}_w, \qquad \mu_w = \frac{1}{\sum_i w_i^2}, \tag{15.24}$$

其中 $c_c \in (0,1]$ 决定记忆长度。μ_w 是有效亲代数，权重越平均越大。系数 $\sqrt{c_c(2-c_c)\mu_w}$ 的来历在下一小节解释。

第三步更新协方差，把三部分加起来：

$$\boldsymbol{\Sigma}^{(t+1)} = (1-c_1-c_\mu)\boldsymbol{\Sigma}^{(t)} + c_1 \boldsymbol{p}_c^{(t+1)}\big(\boldsymbol{p}_c^{(t+1)}\big)^{\top} + c_\mu \sum_{i=1}^{\mu} w_i \boldsymbol{y}_{i:\lambda}\boldsymbol{y}_{i:\lambda}^{\top}. \tag{15.25}$$

第一部分是旧的形状，第二部分来自路径方向，称为秩一更新，第三部分是这一代选中位移的加权协方差，称为秩 μ 更新。

式 (15.25)的 $\boldsymbol{y}_{i:\lambda}$ 是相对旧中心的位移，用的是旧的 $\boldsymbol{m}$。如果用新的 $\boldsymbol{m}$，等于把这一代沿平均方向的进展减掉了，协方差就只记录了后代之间的散布，看不出朝哪边走有好处。

协方差保持正定　抽样要求 $\boldsymbol{\Sigma}$ 正定，下面的引理说明正权重时自动满足。

引理 15.5　协方差更新保持正定　设 $\boldsymbol{\Sigma}^{(t)}$ 对称正定，$c_1, c_\mu \ge 0$，$c_1 + c_\mu < 1$，$w_i > 0$。则由式 (15.25)得到的 $\boldsymbol{\Sigma}^{(t+1)}$ 对称正定。

证明　任取 $\boldsymbol{u} \neq \boldsymbol{0}$，由式 (15.25)，

$$\boldsymbol{u}^{\top}\boldsymbol{\Sigma}^{(t+1)}\boldsymbol{u} = (1-c_1-c_\mu)\boldsymbol{u}^{\top}\boldsymbol{\Sigma}^{(t)}\boldsymbol{u} + c_1\langle \boldsymbol{u}, \boldsymbol{p}_c^{(t+1)}\rangle^2 + c_\mu \sum_i w_i \langle \boldsymbol{u}, \boldsymbol{y}_{i:\lambda}\rangle^2.$$

第一项为正，后两项非负。对称性由三个对称矩阵之和得到。 ■

这里假定权重全为正。有的实现给排序靠后的后代分配负权重，用来主动缩小不好的方向，那时要专门限制幅度，上面的引理不再适用。

变量　下面用目标 (15.22)手算一代。要维护的量是：

- $\boldsymbol{m}^{(t)} \in \mathbb{R}^n$：中心，$\sigma^{(t)} > 0$：整体尺度；
- $\boldsymbol{\Sigma}^{(t)} \in \mathbb{R}^{n\times n}$：形状，对称正定；
- $\boldsymbol{p}_c^{(t)} \in \mathbb{R}^n$：协方差路径，$\boldsymbol{p}_\sigma^{(t)} \in \mathbb{R}^n$：步长路径，下一小节使用；
- 最好记录。整代替换时中心本身未必被评价过，记录必须单独保存。

初始化 中心取 $\boldsymbol{m}^{(0)}$，尺度取一个足以覆盖初始不确定性的量，形状取单位阵，两条路径取零。例中为了手算，把参数取成简单的数：

$$\boldsymbol{m}^{(0)} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}, \qquad \sigma^{(0)} = 1, \qquad \boldsymbol{\Sigma}^{(0)} = \boldsymbol{I}, \qquad \boldsymbol{p}_c^{(0)} = \boldsymbol{p}_\sigma^{(0)} = \boldsymbol{0},$$

$$\lambda = 4, \quad \mu = 2, \quad (w_1, w_2) = \left(\tfrac{3}{4}, \tfrac{1}{4}\right), \quad c_c = \tfrac{1}{2}, \quad c_1 = c_\mu = \tfrac{1}{5}.$$

于是 $\mu_w = 1/(9/16 + 1/16) = 1.6$，路径系数 $\sqrt{c_c(2-c_c)\mu_w} = \sqrt{1.2} \approx 1.095$。此时 $f(\boldsymbol{m}^{(0)}) = 13$。实际运行时参数按维数取默认公式，这里的简单数值只为演示。

每轮更新 第 t 代依次执行以下步骤，直到预算用完或 σ 小到分辨不出差别。

1. 由式 (15.21)抽 λ 个后代并评价，这一步要做 λ 次评价。例中 $\boldsymbol{\Sigma}^{(0)} = \boldsymbol{I}$，取四个位移，后代和代价是

$$\begin{aligned} \boldsymbol{y}_1 &= (-1, -0.6) : \ \boldsymbol{x}_1 = (2, 0.4), \ f = 7.2, \\ \boldsymbol{y}_2 &= (0.5, 0.5) : \ \boldsymbol{x}_2 = (3.5, 1.5), \ f = 15.25, \\ \boldsymbol{y}_3 &= (-0.4, -1) : \ \boldsymbol{x}_3 = (2.6, 0), \ f = 16.9, \\ \boldsymbol{y}_4 &= (1, -0.5) : \ \boldsymbol{x}_4 = (4, 0.5), \ f = 32.625. \end{aligned}$$

2. 按代价排序，更新最好记录。例中顺序就是 $1, 2, 3, 4$，记录为 $(2, 0.4)$，代价 7.2。

3. 由式 (15.23)更新中心。例中

$$\boldsymbol{y}_w = \tfrac{3}{4}\begin{bmatrix} -1 \\ -0.6 \end{bmatrix} + \tfrac{1}{4}\begin{bmatrix} 0.5 \\ 0.5 \end{bmatrix} = \begin{bmatrix} -0.625 \\ -0.325 \end{bmatrix}, \qquad \boldsymbol{m}^{(1)} = \begin{bmatrix} 2.375 \\ 0.675 \end{bmatrix}.$$

   新中心的代价约为 8.83，它没有被评价，这里只是核对。

4. 更新步长路径 $\boldsymbol{p}_\sigma$，见下一小节。

5. 由式 (15.24)更新协方差路径。例中 $\boldsymbol{p}_c^{(0)} = \boldsymbol{0}$，

$$\boldsymbol{p}_c^{(1)} = 1.095\, \boldsymbol{y}_w \approx \begin{bmatrix} -0.685 \\ -0.356 \end{bmatrix}.$$

6. 由式 (15.25)更新协方差。例中秩 μ 部分是

$$\tfrac{3}{4}\begin{bmatrix} 1 & 0.6 \\ 0.6 & 0.36 \end{bmatrix} + \tfrac{1}{4}\begin{bmatrix} 0.25 & 0.25 \\ 0.25 & 0.25 \end{bmatrix} = \begin{bmatrix} 0.8125 & 0.5125 \\ 0.5125 & 0.3325 \end{bmatrix},$$

秩一部分是

$$\boldsymbol{p}_c^{(1)}\big(\boldsymbol{p}_c^{(1)}\big)^{\top} \approx \begin{bmatrix} 0.469 & 0.244 \\ 0.244 & 0.127 \end{bmatrix},$$

于是

$$\boldsymbol{\Sigma}^{(1)} = 0.6\,\boldsymbol{I} + 0.2\,(\text{秩一}) + 0.2\,(\text{秩}\mu) \approx \begin{bmatrix} 0.856 & 0.151 \\ 0.151 & 0.692 \end{bmatrix}.$$

7. 更新 σ，见下一小节。

第一代结束，非对角元从 0 变成了正的 0.151，大特征值 0.946 对应的方向约为 $(0.86, 0.51)$，已经朝山谷方向 $(1,1)$ 倾斜了一点。最终在这一代得到中心 $(2.375, 0.675)$ 与记录 $(2, 0.4)$，后续各代重复以上步骤。

形状在做什么，以及它不是什么 图 15.12取 $n = 2$ 的默认参数（$\lambda = 6$，$\mu = 3$）从 $(5, -1)$ 出发。左图中椭圆起初是圆，几代之后沿山谷拉长，然后整体缩小。右图把 $\boldsymbol{\Sigma}$ 的行列式归一后叠在一起：第 40 代的椭圆长短轴之比的平方约为 7.2，方向与山谷一致，形状接近 $\boldsymbol{A}^{-1}$ 的椭圆（比值为 9）。

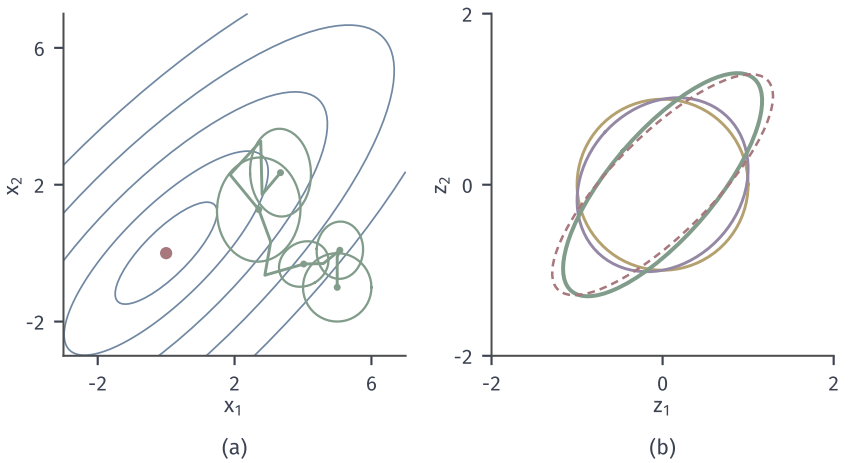


图 15.12 CMA-ES 在式 (15.22)上的一次运行，默认参数，$\lambda = 6$，种子固定。(a) 蓝线是等高线，绿线是中心的路径，绿色椭圆是第 $0, 2, 4, 7, 11$ 代的 $\sigma\boldsymbol{\Sigma}^{1/2}$ 单位圆像。(b) 把 $\boldsymbol{\Sigma}$ 的行列式归一化后的形状：黄线第 0 代，紫线第 6 代，绿线第 40 代，红色虚线是同样归一化的 $\boldsymbol{A}^{-1}$。

在二次目标上，$\boldsymbol{\Sigma}$ 大致正比于 $\boldsymbol{A}^{-1}$ 是可以理解的：作坐标变换 $\boldsymbol{u} = \boldsymbol{A}^{1/2}\boldsymbol{x}$ 后等高线变成圆，而 $\boldsymbol{\Sigma} \propto \boldsymbol{A}^{-1}$ 的抽样在 $\boldsymbol{u}$ 坐标下正好是各向同性的。但这是对运行结果的描述，并不是一个无条件的等式。

15.1 搜索问题
15.2 模拟退火
15.3 演化策略
15.3.1 变异与重组
15.3.2 亲代选择
15.3.3 协方差适应
15.3.4 步长适应
15.3.5 自然演化策略（补充）
15.4 遗传算法
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

一个简单的论证说明两者不可能恒等。CMA-ES 只用排序，所以把 f 换成任何严格递增的函数，比如 $h=\sqrt{f}$，排序完全不变，同一组随机数给出完全相同的 $\mathbf{\Sigma}$ 序列。可是在 $f>0$ 的点，

$$\nabla^2 h=\frac{1}{2\sqrt{f}}\nabla^2 f-\frac{1}{4f^{3/2}}\nabla f\nabla f^{\mathsf{T}},$$

它与 $\nabla^2 f$ 的形状不同。同一个 $\mathbf{\Sigma}$ 不能同时是两者的逆。所以搜索协方差不是目标的 Hessian，也不无条件地等于它的逆；它记录的是最近一段时间里选中位移的分布，并且依赖种群大小和有限的代数。

只用排序的好处恰恰在这里：算法的行为不随 f 的单调变换改变。这是它与第 14章直接用函数值大小构造方向的做法的一个区别。

15.3.4 步长适应

协方差 $\mathbf{\Sigma}$ 描述形状，而 σ 描述整体尺度。把两者分开的理由是：尺度需要比形状快得多的调整。这一小节的问题是：只看选中位移，怎样判断 σ 太大还是太小？

路径长度 连续几代的位移如果彼此同向，说明本可以走得更远，σ 偏小。如果彼此反向、互相抵消，说明走过了头在来回摆动，σ 偏大。

图 15.13(a)(b) 画的就是这两种情形：四段长度差不多的位移，同向时首尾相接的总位移很长，来回抵消时总位移很短。所以要比较的是累计路径的长度与“位移彼此无关时的路径长度”。

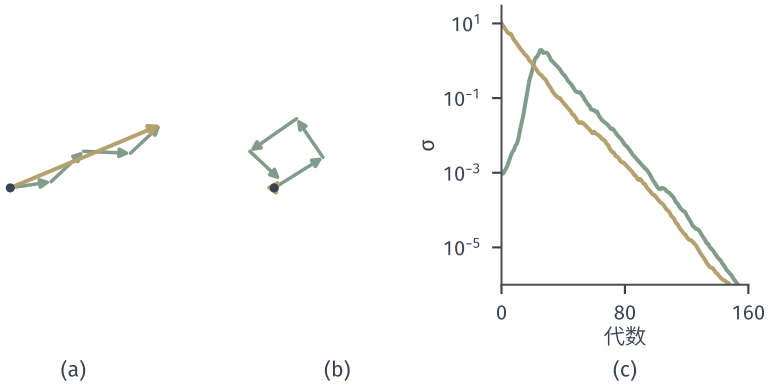


图 15.13 路径长度与步长适应。(a) 四段位移（绿）大致同向，累计位移（黄）长度约 4.8。(b) 四段位移互相抵消，累计位移长度约 0.2。(c) 五维球面 $f=\frac{1}{2}\|\boldsymbol{x}\|_2^2$ 上 σ 随代数的变化，只使用下面的步长路径，从 $\sigma^{(0)}=10^{-3}$（绿）和 $\sigma^{(0)}=10$（黄）出发，纵轴对数刻度。

标准化后累积 为了把形状的影响除掉，累积之前先用 $(\boldsymbol{\Sigma}^{(t)})^{-1/2}$ 把位移变成各向同性：

$$\boldsymbol{p}_\sigma^{(t+1)} = (1-c_\sigma)\boldsymbol{p}_\sigma^{(t)} + \sqrt{c_\sigma(2-c_\sigma)\mu_w}\,\big(\boldsymbol{\Sigma}^{(t)}\big)^{-1/2}\boldsymbol{y}_w. \tag{15.26}$$

再把路径长度与标准正态向量的期望长度比较，据此调整尺度：

$$\sigma^{(t+1)} = \sigma^{(t)}\exp\!\Big(\frac{c_\sigma}{d_\sigma}\Big(\frac{\|\boldsymbol{p}_\sigma^{(t+1)}\|_2}{\mathbb{E}\|\boldsymbol{z}\|_2} - 1\Big)\Big), \qquad \boldsymbol{z}\sim\mathcal{N}(\mathbf{0},\boldsymbol{I}). \tag{15.27}$$

其中 $d_\sigma > 0$ 是阻尼。路径偏长时 σ 增大，偏短时 σ 减小。

系数的选取有一个清楚的理由。设选择完全随机，即排序与位移无关。这时 $\boldsymbol{y}_w \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma}^{(t)}/\mu_w)$，于是 $\sqrt{\mu_w}(\boldsymbol{\Sigma}^{(t)})^{-1/2}\boldsymbol{y}_w$ 是标准正态向量，记为 $\boldsymbol{\xi}$。

若 $\boldsymbol{p}_\sigma^{(t)}$ 也是标准正态向量，且与 $\boldsymbol{\xi}$ 独立，那么式 (15.26)的两项之和仍是高斯向量，协方差的系数为

$$(1-c_\sigma)^2 + c_\sigma(2-c_\sigma) = 1.$$

所以随机选择下路径的分布不变，$\|\boldsymbol{p}_\sigma\|_2$ 的期望等于比较基准，σ 在对数尺度上没有系统漂移。式 (15.24)的系数是同一个道理。一旦有真实选择，路径的长度偏离基准才来自评价信息。

例中的这一步 接上一小节的第一代，取 $c_\sigma = 1/2$，$d_\sigma = 1$，$\boldsymbol{\Sigma}^{(0)} = \boldsymbol{I}$，所以由式 (15.26)，

$$\boldsymbol{p}_\sigma^{(1)} = 1.095\,\boldsymbol{y}_w \approx \begin{bmatrix} -0.685 \\ -0.356 \end{bmatrix}, \qquad \|\boldsymbol{p}_\sigma^{(1)}\|_2 \approx 0.772.$$

二维时 $\boldsymbol{z}$ 的期望长度是 $\sqrt{\pi/2} \approx 1.253$。由式 (15.27)，

$$\sigma^{(1)} = \exp\!\Big(\tfrac{1}{2}\Big(\tfrac{0.772}{1.253} - 1\Big)\Big) \approx \exp(-0.192) \approx 0.825.$$

路径比基准短，尺度缩小。第一代的路径从零开始，只积累了一代，这个判断偏保守。

图 15.13(c) 是这个规则的效果。σ 起初只有 10^{-3} 时，路径持续同向，σ 在约 25 代内升到接近 2；起初为 10 时，σ 直接下降。之后两条线都随着接近最优点按稳定的比例减小，代价在 160 代后约为 10^{-13} 量级。

两条路径的职责 两条路径形式相近，用途不同，表 15.5是对比。

15.1 搜索问题
15.2 模拟退火
15.3 演化策略
15.3.1 变异与重组
15.3.2 亲代选择
15.3.3 协方差适应
15.3.4 步长适应
15.3.5 自然演化策略（补充）
15.4 遗传算法
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

表 15.5 两条演化路径。

	协方差路径 $\boldsymbol{p}_c$	步长路径 $\boldsymbol{p}_\sigma$
累积的量	$\boldsymbol{y}_w$，含形状	$\boldsymbol{\Sigma}^{-1/2}\boldsymbol{y}_w$，已标准化
用到它的什么	方向和符号相关	长度
更新谁	$\boldsymbol{\Sigma}$（秩一项）	σ

更新顺序与数值处理 一代内的次序是：抽样和评价；更新 $\boldsymbol{m}$；用旧的 $\boldsymbol{\Sigma}$ 更新 $\boldsymbol{p}_\sigma$；更新 $\boldsymbol{p}_c$；更新 $\boldsymbol{\Sigma}$；最后更新 σ。把 $\boldsymbol{\Sigma}$ 的更新放在 σ 之前，是因为式 (15.25)中的 $\boldsymbol{y}_{i:\lambda}$ 已按抽样时的 $\sigma^{(t)}$ 标准化，这时不需要新的尺度。

实际实现还有一个小的修正：当 $\|\boldsymbol{p}_\sigma\|_2$ 异常大，说明 σ 正在快速调整，这时暂停式 (15.24)右端的累积，防止形状被一次快速移动带偏。

代价方面，抽样要用 $\boldsymbol{\Sigma}^{1/2}$，$\boldsymbol{p}_\sigma$ 要用 $\boldsymbol{\Sigma}^{-1/2}$，这需要对称特征分解，稠密时一次约 $O(n^3)$。通常每隔若干代才重新分解一次，把平均开销压到每次评价 $O(n^2)$。

数值上要防止协方差病态：每次分解前把 $\boldsymbol{\Sigma}$ 强制对称化，检查最小特征值是否仍为正，条件数太大时重置或停止。式 (15.27)的指数形式保证 σ 恒正，无需额外处理。

15.3.5 自然演化策略（补充）

前面的更新公式是逐条设计的。这一小节换一个角度：能不能把搜索分布的参数本身当作优化变量，直接写出它的梯度下降？这样得到的方法称为**自然演化策略**（natural evolution strategy，NES）。

分布参数上的目标 设搜索分布 q_θ 由参数 θ 决定，把期望代价作为 θ 的函数：

$$J(\theta)=\mathbb{E}_{\boldsymbol{x}\sim q_\theta}[f(\boldsymbol{x})]=\int f(\boldsymbol{x})q_\theta(\boldsymbol{x})\,\mathrm{d}\boldsymbol{x}. \tag{15.28}$$

$\boldsymbol{x}$ 可以是离散的，f 可以不可微，只要 q_θ 对 θ 光滑。在可交换微分与积分的条件下，

$$\nabla_\theta J(\theta)=\int f(\boldsymbol{x})\nabla_\theta q_\theta(\boldsymbol{x})\,\mathrm{d}\boldsymbol{x}.$$

再把 ∇q 写成 $q\nabla\log q$，得到可以用样本估计的形式：

$$\nabla_\theta J(\theta)=\mathbb{E}_{\boldsymbol{x}\sim q_\theta}\big[f(\boldsymbol{x})\nabla_\theta\log q_\theta(\boldsymbol{x})\big]. \tag{15.29}$$

其中 $\nabla_\theta\log q_\theta$ 称为**得分函数**（score function）。

与平滑估计的交叉 取 $q=\mathcal{N}(\boldsymbol{m},\sigma^2\boldsymbol{I})$，只把中心 $\boldsymbol{m}$ 当参数，σ 固定。写 $\boldsymbol{x}=\boldsymbol{m}+\sigma\boldsymbol{z}$，得分是

$$\nabla_{\boldsymbol{m}}\log q=\frac{\boldsymbol{x}-\boldsymbol{m}}{\sigma^2}=\frac{\boldsymbol{z}}{\sigma}.$$

代入式 (15.29)，有

$$\nabla_{\boldsymbol{m}}J=\frac{1}{\sigma}\mathbb{E}_{\boldsymbol{z}}\big[f(\boldsymbol{m}+\sigma\boldsymbol{z})\boldsymbol{z}\big]. \tag{15.30}$$

这里的 J 把 f 在 $\boldsymbol{m}$ 周围按高斯权重做了平均，这正是第 14章的高斯平滑目标，式 (15.30)正是那里的高斯方向估计。在这一实例上，分布梯度和平滑梯度是同一件事，这就是本节开头说的两种视角的重合。

一个可手算的例子：$f(x)=x^2$，$q=\mathcal{N}(m,\sigma^2)$，$m=2$，$\sigma=1$。这时精确值是 $J=m^2+\sigma^2$，$\partial_m J=2m=4$。取两个样本 $z=\pm1$，读数为 $f(3)=9$，$f(1)=1$，估计值为

$$\frac{1}{2}\big(9\cdot 1+1\cdot(-1)\big)=4,$$

恰好是精确值。一般样本下估计值有方差，只有期望等于 $2m$。

基线 由于 $\mathbb{E}[\nabla\log q]=\boldsymbol{0}$，给 f 减去一个常数 b 不改变期望，却改变方差。上例中估计量 $(f(m+z)-b)z$ 的方差可以逐项算出。

记 $a=m^2-b$，把 $(m+z)^2-b$ 展开，估计量等于 $az+2mz^2+z^3$，用 $\mathbb{E}z^2=1$，$\mathbb{E}z^4=3$，$\mathbb{E}z^6=15$，奇数阶矩为零，得到

$$\mathrm{Var}=a^2+6a+15+8m^2.$$

$m=2$ 时，$b=0$（$a=4$）的方差是 87；$b=5$（$a=-1$）的方差是 42；$b=7$（$a=-3$）的方差最小，是 38。基线不改变估计的目标，只改变噪声大小。

自然梯度 普通梯度依赖参数怎样写。把 σ 换成 $\log\sigma$，梯度的方向就变了，可分布族是同一个。自然的办法是用分布之间的差别来度量参数的变化，即用Fisher 信息矩阵（Fisher information matrix）

$$\boldsymbol{F}(\theta)=\mathbb{E}_{\boldsymbol{x}\sim q_\theta}\big[\nabla_\theta\log q_\theta(\boldsymbol{x})\nabla_\theta\log q_\theta(\boldsymbol{x})^{\top}\big] \tag{15.31}$$

作度量，沿**自然梯度**（natural gradient）下降：

$$\theta^{(t+1)}=\theta^{(t)}-\eta\,\boldsymbol{F}(\theta^{(t)})^{-1}\nabla_\theta J(\theta^{(t)}). \tag{15.32}$$

一维高斯 $\theta=(m,\sigma)$，得分是 $(z/\sigma,(z^2-1)/\sigma)$，由 $\mathbb{E}z^2=1,\mathbb{E}(z^2-1)^2=2$，交叉项为 $\mathbb{E}z(z^2-1)=0$，得

$$\boldsymbol{F}=\begin{bmatrix}1/\sigma^2 & 0\\ 0 & 2/\sigma^2\end{bmatrix}.$$

还是目标 $J=m^2+\sigma^2$，普通梯度是 $(2m,2\sigma)$，自然梯度是

$$\boldsymbol{F}^{-1}\nabla J=(2m\sigma^2,\ \sigma^3).$$

在 $(m,\sigma)=(2,1)$，普通梯度是 $(4,2)$，自然梯度是 $(4,1)$。

图 15.14比较两条连续轨迹。普通梯度沿直线同比例缩小 m 和 σ。自然梯度下由 $\mathrm{d}m/\mathrm{d}\sigma=2m/\sigma$ 得 $m\propto\sigma^2$，均值比宽度收得快，分布先把中心挪到位，再缩小探索范围。

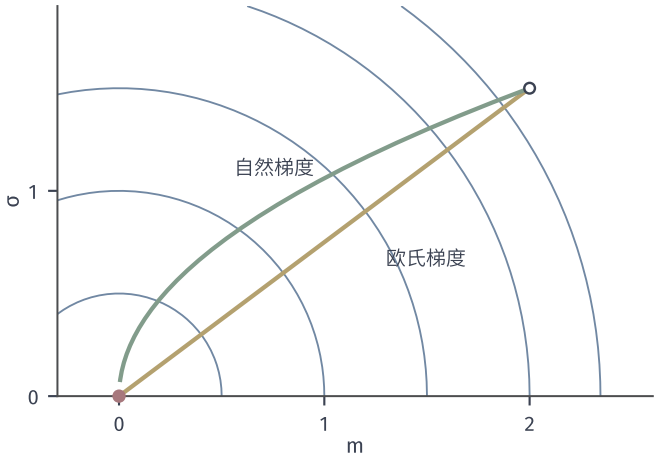


图 15.14　分布参数平面上的两条下降路径，$J(m,\sigma)=m^2+\sigma^2$，蓝线是 J 的等值线，空心圆是起点 $(2,1.5)$，红点是最小点。黄线沿普通梯度，绿线沿自然梯度，后者满足 $m\propto\sigma^2$。

和 CMA-ES 的关系，以及要核对什么　把 θ 限于中心，并把 f 换成按排序给的效用：选中的后代权重 w_i，其余为 0。对 $\mathcal{N}(\boldsymbol{m},\sigma^2\boldsymbol{\Sigma})$，Fisher 矩阵的均值块是 $(\sigma^2\boldsymbol{\Sigma})^{-1}$，自然梯度下的均值更新量是

$$\sigma^2\boldsymbol{\Sigma}\cdot\sum_i w_i(\sigma^2\boldsymbol{\Sigma})^{-1}(\boldsymbol{x}_{i:\lambda}-\boldsymbol{m})=\sigma\sum_i w_i\boldsymbol{y}_{i:\lambda},$$

这正是式 (15.23)。

这里有一点要小心：把 f 换成排序效用后，优化的已经不是原来的 J，排序依赖当前样本，估计量也不再是式 (15.29)的无偏估计。基线只改变方差，排序效用改变了目标，把尺度参数写成 σ 还是 $\log\sigma$ 则改变普通梯度

的方向，这三件事不能混为一谈。说一个更新“是梯度下降”时，要先说清是哪个目标、哪个估计量、哪种度量。

15.1 搜索问题
15.2 模拟退火
15.3 演化策略
15.4 遗传算法
15.4.1 候选解的编码
15.4.2 亲代选择
15.4.3 交叉与变异
15.4.4 后代替换
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

15.4 遗传算法

演化策略的搜索分布依赖连续变量的高斯结构，换到开关选择或排列上就用不上了。于是要问：候选是离散的编码时，怎样利用一批已评价的候选产生新的候选？**遗传算法**（genetic algorithm，GA）的做法是：维护一个种群，用评价选出亲代，把亲代的编码拼接和改动，得到新的候选。

“基因”“繁殖”只是沿用下来的名称。这些类比并不告诉我们一个操作在实际问题上做了什么。下面把四件事分开说明：候选的编码、亲代的选择、新候选的产生、下一代的组成。

15.4.1 候选解的编码

遗传算法的操作都作用在编码上。这一小节的问题是：候选应当怎样写成编码，编码与原问题的解是什么关系？

选择问题：0–1 串　全节用一个背包问题作例子。有六件物品，第 j 件价值 v_j、重量 w_j，容量为 15：

$$\boldsymbol{v} = (6, 5, 8, 9, 6, 7), \qquad \boldsymbol{w} = (2, 3, 6, 7, 5, 9).$$

用串 $\boldsymbol{b} \in \{0,1\}^6$ 表示选择，$b_j = 1$ 表示选第 j 件。要最小化的是价值的相反数：

$$f(\boldsymbol{b}) = -\sum_{j=1}^{6} v_j b_j, \qquad \text{约束} \quad \sum_{j=1}^{6} w_j b_j \le 15. \tag{15.33}$$

例如 $\boldsymbol{b} = 101100$ 选第 $1, 3, 4$ 件，总重 15，$f = -23$。穷举全部 $2^6 = 64$ 个串可知这正是最优解，总共 30 个可行串。

解码（decoding）是从编码回到原问题的解，评价永远在解码之后进行。这里编码与解是一一对应的，解码平凡，但重量约束使得并非每个串都可行，第 15.6节处理这一点。

顺序问题：排列　访问顺序、任务排程的自然编码是排列，第 15.1.1节的 *ABDCE* 就是一个例子，排列本身就是解。

把排列硬写成二进制会带来麻烦。五个元素每个用三位表示，一共 15 位，有 $2^{15} = 32768$ 种串，其中只有 $5! = 120$ 种是合法排列，约占 0.37%。翻一位多半得到重复元素的串，算法大部分精力花在非法候选上。

15.1 搜索问题
15.2 模拟退火
15.3 演化策略
15.4 遗传算法
15.4.1 候选解的编码
15.4.2 亲代选择
15.4.3 交叉与变异
15.4.4 后代替换
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

连续变量 连续变量可以直接用实数向量编码，第 15.8节的比较实验就是这样做的，这时“交叉”是两个实数向量的组合，“变异”是加一个小扰动。

编码决定了什么叫“邻近”，决定了哪些操作合法，所以不存在一种通用的串表示。写清楚编码的含义、解码方式和合法操作，是这类算法要做的第一件事。

15.4.2 亲代选择

有了种群和评价，下一个问题是：谁来产生下一代的候选？选得太偏向好个体，种群很快只剩少数几种；选得太平均，又等于随机游走。用同一组数比较几种规则。设种群有 $N = 5$ 个候选，代价从好到差为

$$(f_{1:5}, \dots, f_{5:5}) = (-24, -20, -19, -15, -10). \tag{15.34}$$

排序选择 把候选按代价排序，只按名次分配概率。线性排序取参数 $s \in (1, 2]$，第 r 名被选中的概率是

$$p_r = \frac{1}{N}\Big(2 - s + 2(s-1)\frac{N-r}{N-1}\Big). \tag{15.35}$$

$s = 1.5$，$N = 5$ 时，五个名次的概率是

$$(0.30,\ 0.25,\ 0.20,\ 0.15,\ 0.10).$$

由于只用名次，把代价做单调变换不影响选择。

锦标赛选择 锦标赛选择（tournament selection）每次有放回地抽 k 个候选，选其中代价最小的。它不需要排序全体，也只用比较结果。第 r 名被选中，当且仅当这 k 次抽样都不比第 r 名更好（共有 $N - r + 1$ 个这样的候选可抽），并且至少有一次抽到了第 r 名。所以

$$p_r = \frac{(N-r+1)^k - (N-r)^k}{N^k}. \tag{15.36}$$

这里默认没有并列。

$N = 5$，$k = 2$ 时，五个名次的概率是

$$(0.36,\ 0.28,\ 0.20,\ 0.12,\ 0.04).$$

$k = 3$ 时是

$$(0.488,\ 0.296,\ 0.152,\ 0.056,\ 0.008).$$

15.1 搜索问题
15.2 模拟退火
15.3 演化策略
15.4 遗传算法
15.4.1 候选解的编码
15.4.2 亲代选择
15.4.3 交叉与变异
15.4.4 后代替换
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

k 越大，好候选被选中的倾向越强。这种倾向称为**选择压力**（selection pressure）。以第 1 名在 N 次选择中的期望份数 Np_1 度量，$k=2$ 时是 1.8 份，$k=3$ 时是 2.44 份。

比例选择要先转换　经典的比例选择把选中概率设为正比于**适应度**（fitness）F。最小化问题的代价不能直接拿来用：代价越低越好，比例却是数越大份额越大，方向就是反的。

把式 (15.34)的代价都加上 20，问题没有变，五个数成为 $(-4,0,1,5,10)$，总和是 12，第一个比值是负数，根本不是概率。

必须先指定从代价到非负权重的转换。一种做法是以当前最差者为基准：

$$F_i = f_{\max} - f_i + \delta, \qquad \delta > 0. \tag{15.37}$$

取 $\delta=1$，得到权重 $(15,11,10,6,1)$，总和为 43，五个概率约为

$$(0.349,\ 0.256,\ 0.233,\ 0.140,\ 0.023).$$

这个转换对代价的平移不变，但概率依赖代价差的相对大小，也依赖 δ 的取值，把 δ 取大，选择会趋于均匀。图 15.15把几种规则画在一起。

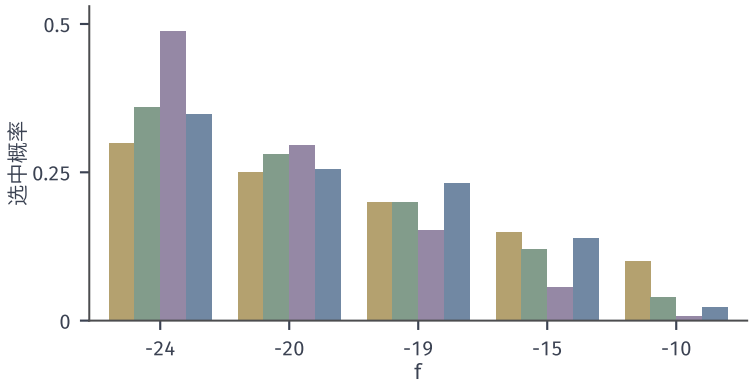


图 15.15　同一组代价 (15.34)下五个候选的选中概率，从左到右依次为线性排序（黄，$s=1.5$）、二元锦标赛（绿）、三元锦标赛（紫）、比例选择（蓝，$\delta=1$）。

15.4.3 交叉与变异

选出亲代以后，怎样产生新候选？有两种操作，职责不同。**交叉**（crossover）把两个亲代已有的片段重新组合，只能产生两个亲代片段的拼接。**变异**（mutation）改动个别位置，引入亲代都没有的内容。

二进制串 **单点交叉**随机选一个切点，交换切点后的尾部。用两个亲代

$$\boldsymbol{a} = 110\,100, \qquad \boldsymbol{b} = 101\,010,$$

切点在第 3 位之后。

$\boldsymbol{b}$ 的前三位接 $\boldsymbol{a}$ 的后三位，得到 101 100；$\boldsymbol{a}$ 的前三位接 $\boldsymbol{b}$ 的后三位，得到 110 010。第一个后代正是最优解 101100，$f = -23$，比两个亲代的 -20 都好。第二个后代 110010 总重 10，$f = -17$，比两个亲代都差。交叉只是重新组合，不保证任何一个后代更好。

逐位变异对每一位独立以概率 p_m 翻转，常取 $p_m = 1/n$，平均每个串翻一位。图 15.16(a) 中第二个后代的第 4 位翻转，变成 110110。这个串总重 17，超过容量，是不可行的。

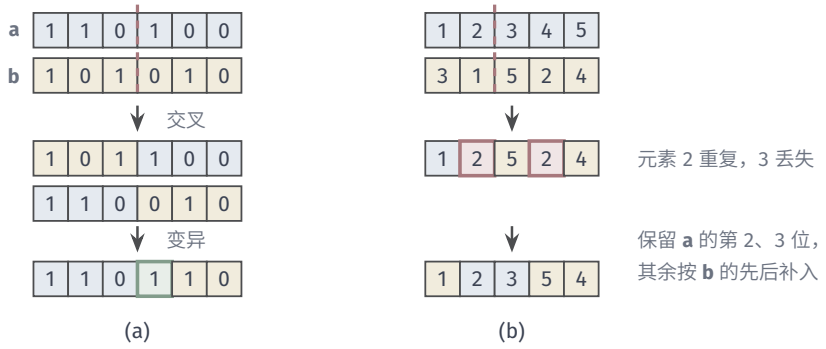


图 15.16 二进制串与排列上的操作。蓝色格来自亲代 $\boldsymbol{a}$，黄色格来自亲代 $\boldsymbol{b}$，红色虚线是切点。(a) 单点交叉后，第二个后代的第 4 位变异（绿框）。(b) 在排列上直接交换尾部会产生重复元素（红框）；保留 $\boldsymbol{a}$ 的中段再按 $\boldsymbol{b}$ 的先后顺序补入其余元素，得到合法排列。

排列要用保持排列的算子 排列上的单点交叉会出错。$\boldsymbol{a} = 12345$，$\boldsymbol{b} = 31524$，切点在第 2 位之后，直接拼接得到 12 524，元素 2 出现两次，元素 3 丢失，已经不是排列。

有两种处理办法：换用保持排列的算子，或者明确规定修复规则。**顺序交叉**属于前者：保留 $\boldsymbol{a}$ 的第 2、3 位，即 23，其余位置按 $\boldsymbol{b}$ 中出现的先后依次填入尚未使用的元素，$\boldsymbol{b}$ 的顺序去掉 2, 3 后是 1, 5, 4，于是得到 12354。排列上的变异也用交换两个位置或翻转一段，而不用单独改一个位置。

两组参数分开记录 交叉概率 p_c 是一对亲代发生交叉的概率，不交叉时后代直接复制亲代。变异概率 p_m 是每一位翻转的概率，作用范围是一位而不是一个串。两者要分别记录。

15.1 搜索问题
15.2 模拟退火
15.3 演化策略
15.4 遗传算法
15.4.1 候选解的编码
15.4.2 亲代选择
15.4.3 交叉与变异
15.4.4 后代替换
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

两种操作各自都不保证改善目标。上面的例子里，同一次交叉同时给出了最好的和较差的后代，一次变异把后代变得不可行。质量的提升要靠后面的选择来累积。

15.4.4 后代替换

亲代选择决定谁来产生新候选，后代替换决定谁进入下一代，两者是两个独立的决定。

三种替换 **整代替换**用后代完全替代上一代。**精英保留**（elitism）在整代替换的基础上把上一代最好的若干个直接带入下一代。**逐个替换**每产生一个后代，就让它替换当前种群中最差的个体，如果它比那个个体好的话。

变量 下面在背包问题上走完一代。要维护的量是：

- 种群 $\boldsymbol{b}_1, \dots, \boldsymbol{b}_N$ 及其代价，N 是种群规模；
- 历史最好可行解及其代价。

初始化 产生初始种群并评价，这一步消耗 N 次评价。例中 $N = 4$，初始种群是

$$A = 110100\ (\text{重}12,\ f = -20), \qquad B = 101010\ (\text{重}13,\ f = -20),$$
$$C = 011010\ (\text{重}14,\ f = -19), \qquad D = 100110\ (\text{重}14,\ f = -21).$$

最好记录是 D，代价 -21。超重的串在选择时用罚项代价 $f + 10\times$（超重量），第 15.6节再比较其他做法。

每轮更新 每一代重复以下步骤，直到预算用完。

1. 用二元锦标赛选两个亲代。例中第一次比较 (B, C)，胜者 B；第二次比较 (A, C)，胜者 A。
2. 按 p_c 决定是否交叉。例中切点在第 3 位之后，得到 101100 和 110010。
3. 按 p_m 逐位变异。例中第一个后代不变，第二个后代第 4 位翻转，成为 110110。
4. 解码并评价后代，更新历史最好可行解。例中 101100 总重 15，$f = -23$，可行，记录更新。110110 总重 17，价值 26，$f = -26$，超重 2，罚项代价为

$$-26 + 10 \times 2 = -6.$$

这个串的 f 虽低，却不能进入可行解的记录。

5. 重复第 1 到 4 步，直到得到 N 个后代。例中第二对亲代的比较为 (D, A)，胜者 D；(C, C) 抽到同一个候选，C 胜出。切点在第 2 位之后，无变异，得到 101010（$f = -20$）和 010110（重 15，$f = -20$）。

6. 组成下一代。整代替换时下一代是这四个后代；精英保留一个时，D 取代后代中最差的 110110。

这一代消耗 4 次评价。最终得到历史最好可行解 101100，它是这个问题的最优解。

三种替换的结果放在表 15.6中。这次后代中有更好的解，三种规则的最好值都是 -23；差别在于下一代的其余成员。如果这一代的后代都很差，整代替换会使种群的最好值变差，精英保留和逐个替换不会。

表 15.6 同一代的三种替换结果，第三列是对应的选择用代价。

规则	下一代	代价
整代替换	101100, 110110, 101010, 010110	$-23, -6, -20, -20$
精英保留	101100, 100110, 101010, 010110	$-23, -21, -20, -20$
逐个替换	110100, 101010, 101100, 100110	$-20, -20, -23, -21$

逐个替换那一行的过程是：101100 替换当时最差的 $C(-19)$；110110 的 -6 比当前最差的 -20 差，不替换；后两个后代的 -20 与最差者持平，规定严格更好才替换，所以也不替换。

多样性的丢失 种群有一个专门的失败方式：所有成员越来越像。把多样性度量为种群中两个不同成员平均相差的位数占总位数的比例。若某一位全种群都相同，交叉再怎么拼接，这一位也不会改变，只有变异才能恢复。

图 15.17在一个 40 件物品的背包问题上比较两种变异率，种群 $N = 30$，二元锦标赛，单点交叉，精英保留一个。没有变异时，多样性约 20 代内降到 0，种群变成同一个串，此后每一代的后代都与亲代相同，相对最优值的间隙卡在约 15%。变异率 $1/40$ 时多样性稳定在约 0.2，150 代后间隙约为 1.4%。

15.1 搜索问题
15.2 模拟退火
15.3 演化策略
15.4 遗传算法
15.5 粒子群
15.5.1 个人与群体记忆
15.5.2 速度与位置更新
15.5.3 移动尺度与停滞
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

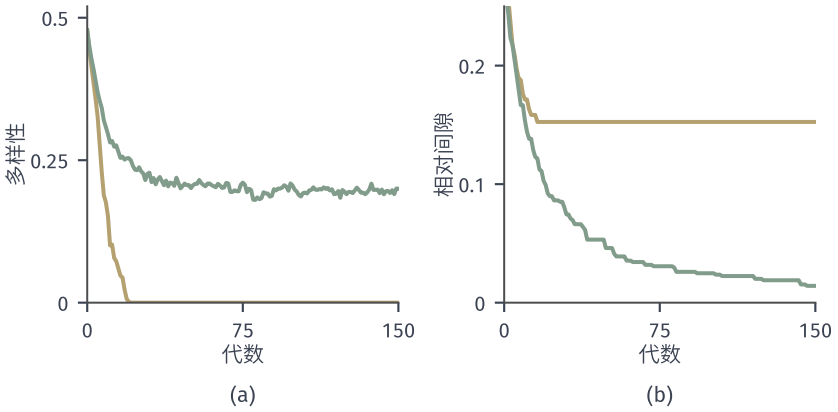


图 15.17　40 件物品的背包问题，31 次运行的中位数。黄线不变异，绿线变异率 1/40。(a) 种群多样性，即两个不同成员平均相差的位数占总位数的比例。(b) 历史最好可行解与最优价值的相对间隙，最优价值由动态规划算出。

保持多样性的手段有三个：变异持续注入新内容；较大的种群让位点的多样性丢失得慢；种群收敛后保留最好记录并重启。它们都消耗评价次数，要在预算内权衡。

精英保留也不能提供有限预算下的全局保证。它只保证种群的最好值不变差，这和第 15.3.2节的结论相同，精英甚至可能加速多样性的丢失，因为它的片段被反复选中。

15.5 粒子群

演化策略让分布移动，遗传算法重组编码。还有一种组织方式：让每个候选都带着速度在连续空间中移动，并记住自己和同伴到过的好位置。这称为**粒子群优化**（particle swarm optimization，PSO）。接下来要弄清：怎样利用已发现的位置引导移动，移动的幅度由什么控制？

可以把它想成一群人在雾中找谷底，每人记得自己到过的最低处，也听得到一些同伴报告的最低处。每一步他沿惯性继续走，同时被这两个记忆的方向拉一下。这个比喻只对应更新公式的结构，不能推出任何收敛性质。

15.5.1 个人与群体记忆

粒子的移动依赖记忆。这一小节的问题是：每个粒子要记住什么，同伴之间共享什么？

完整状态　设有 N 个粒子，变量是 $\boldsymbol{x} \in \mathbb{R}^n$。第 i 个粒子第 t 步的状态由四个量组成：

- 位置 $\boldsymbol{x}_i^{(t)}$：当前候选；

- 速度 $\boldsymbol{v}_i^{(t)}$：上一步的位移，不是目标的导数；
- **个人最好位置**（personal best）$\boldsymbol{p}_i^{(t)}$：这个粒子到过的最好位置；
- **邻域最好位置**（neighborhood best）$\boldsymbol{g}_i^{(t)}$：指定邻域内各粒子的个人最好位置中最好的一个。

本节的 $\boldsymbol{g}_i$ 是位置，不是梯度。

初始化时在搜索区域内均匀抽位置，抽较小的初速度，评价一遍，令 $\boldsymbol{p}_i^{(0)} = \boldsymbol{x}_i^{(0)}$，然后由定义得到 $\boldsymbol{g}_i^{(0)}$。

个人记忆的更新规则是：

$$\boldsymbol{p}_i^{(t+1)} = \begin{cases} \boldsymbol{x}_i^{(t+1)}, & f(\boldsymbol{x}_i^{(t+1)}) < f(\boldsymbol{p}_i^{(t)}), \\ \boldsymbol{p}_i^{(t)}, & \text{否则}. \end{cases} \tag{15.38}$$

相同评价值时规定不更新，这样结果不依赖浮点上的偶然差别。在邻域内比较时，若有并列，按粒子编号取最小者，也要事先固定。

共享范围 图 15.18是两种共享方式。**全局共享**时所有粒子彼此相连，$\boldsymbol{g}_i$ 对所有 i 相同，就是全体个人记忆中最好的一个。**局部邻域**时每个粒子只与环上的相邻粒子交换信息，好位置要经过多步才能传遍全群。

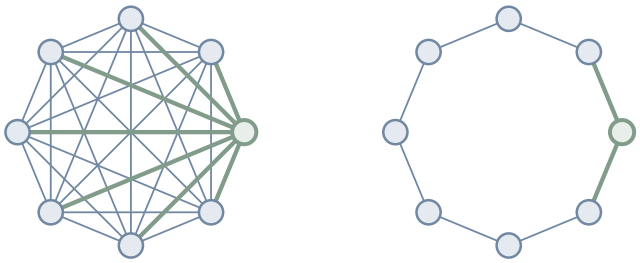


图 15.18 八个粒子的两种信息共享方式，绿色圆是当前关注的粒子，绿线是它能直接获知的同伴。(a) 全局共享：每个粒子能看到其他所有粒子。(b) 环形邻域：只与左右两个粒子交换。

全局共享传播快，全群容易一起挤向同一个地方；环形邻域传播慢，不同区段可以暂时朝不同的好位置移动，保留较多的探索。

同步与异步 实现上有两种顺序。**同步**更新时，一轮内所有粒子都用上一轮结束时的记忆移动，全部评价完再统一更新记忆，这便于并行评价。**异步**更新时，每评价完一个粒子，立即更新记忆，后面的粒子马上能用到新发现。两者的结果不同，记录算法时要写清楚用的是哪一种。下面用同步。

15.1 搜索问题
15.2 模拟退火
15.3 演化策略
15.4 遗传算法
15.5 粒子群
15.5.1 个人与群体记忆
15.5.2 速度与位置更新
15.5.3 移动尺度与停滞
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

15.5.2 速度与位置更新

有了状态和记忆，这一小节写出一步更新的公式，并按实际的次序算一遍。

主要思想 新速度由三部分叠加：沿旧速度的惯性，朝个人记忆的拉力，朝邻域记忆的拉力。两个拉力的强度带随机性，以避免所有粒子沿同一条确定的轨迹运动：

$$\begin{aligned} \boldsymbol{v}_i^{(t+1)} &= \boldsymbol{v}_i^{(t)} + c_1 \boldsymbol{r}_1 \odot \left(\boldsymbol{p}_i^{(t)} - \boldsymbol{x}_i^{(t)}\right) + c_2 \boldsymbol{r}_2 \odot \left(\boldsymbol{g}_i^{(t)} - \boldsymbol{x}_i^{(t)}\right), \\ \boldsymbol{x}_i^{(t+1)} &= \boldsymbol{x}_i^{(t)} + \boldsymbol{v}_i^{(t+1)}, \end{aligned} \tag{15.39}$$

其中 $c_1, c_2 > 0$ 是吸引系数，$\odot$ 表示按分量相乘，$\boldsymbol{r}_1, \boldsymbol{r}_2$ 的各个分量独立地均匀取自 $[0,1]$，并且对每个粒子、每一轮重新抽取。

这里的差 $\boldsymbol{p}_i - \boldsymbol{x}_i$ 和 $\boldsymbol{g}_i - \boldsymbol{x}_i$ 只是到记忆位置的位移，不是目标的梯度。在下面的例子里 $\boldsymbol{x} = (4,2)$，负梯度是 $(-4,-18)$，朝邻域记忆的位移是 $(-3,-1)$，两者的夹角约为 $59°$。粒子可以朝一个代价更高的方向飞，因为记忆里的点在那边。

变量 一个粒子需要 $\boldsymbol{x}$、$\boldsymbol{v}$、$\boldsymbol{p}$、$\boldsymbol{g}$，以及 $f(\boldsymbol{p})$；全局还要保存历史最好记录。

初始化 下面用 $f(\boldsymbol{x}) = \frac{1}{2}(x_1^2 + 9x_2^2)$ 核对一步。设系数 $c_1 = c_2 = 1.5$，粒子当前状态是

$$\boldsymbol{x} = \begin{bmatrix} 4 \\ 2 \end{bmatrix}, \quad \boldsymbol{v} = \begin{bmatrix} -1 \\ 0.5 \end{bmatrix}, \quad \boldsymbol{p} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}, \quad \boldsymbol{g} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

记忆处的代价是 $f(\boldsymbol{p}) = 9$，$f(\boldsymbol{g}) = 5$。

每轮更新 每一轮按下面的次序处理每个粒子，用完预算为止。

1. 抽随机向量。例中

$$\boldsymbol{r}_1 = \begin{bmatrix} 0.5 \\ 0.2 \end{bmatrix}, \qquad \boldsymbol{r}_2 = \begin{bmatrix} 0.4 \\ 0.6 \end{bmatrix}.$$

2. 由式 (15.39)计算新速度。例中个人项和群体项分别是

$$1.5\,\boldsymbol{r}_1 \odot (\boldsymbol{p} - \boldsymbol{x}) = \begin{bmatrix} -0.75 \\ -0.3 \end{bmatrix}, \qquad 1.5\,\boldsymbol{r}_2 \odot (\boldsymbol{g} - \boldsymbol{x}) = \begin{bmatrix} -1.8 \\ -0.9 \end{bmatrix},$$

加上旧速度得到

$$\boldsymbol{v}^{+} = \begin{bmatrix} -3.55 \\ -0.7 \end{bmatrix}.$$

3. 计算新位置并评价。例中

$$\boldsymbol{x}^{+} = \begin{bmatrix} 0.45 \\ 1.3 \end{bmatrix}, \qquad f(\boldsymbol{x}^{+}) = \tfrac{1}{2}(0.2025 + 15.21) \approx 7.71.$$

4. 完成评价后更新记忆。例中 $7.71 < 9$，个人记忆更新为 $(0.45, 1.3)$；$7.71 > 5$，邻域记忆 $\boldsymbol{g}$ 不变。

图 15.19把这一步的三段位移画成首尾相接的箭头。这个粒子一步就把代价从 26 降到了约 7.71，主要靠群体项。

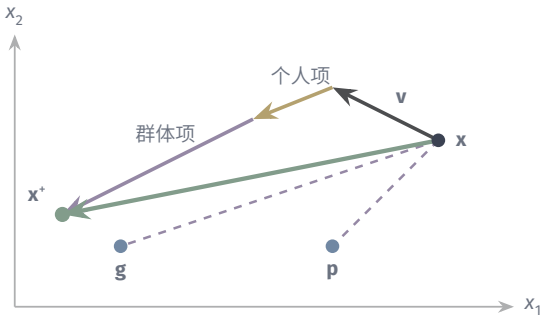


图 15.19　粒子的一步更新。深灰箭头是旧速度，黄箭头是个人项，紫箭头是群体项，绿箭头是合成的实际位移，虚线连向两个记忆位置。两个拉力分量的比例来自随机向量，所以合成位移不必指向任何一个记忆位置。

速度限幅的计算　实际常把速度各分量限制在 $[-v_{\max}, v_{\max}]$ 内。此时必须用修正后的速度计算位移。例中取 $v_{\max} = 2$，$\boldsymbol{v}^{+}$ 被截断为 $(-2, -0.7)$，新位置是 $(2, 1.3)$，代价约为 9.61。这比 $f(\boldsymbol{p}) = 9$ 大，这一步个人记忆就不更新了。

记录下来的 $\boldsymbol{v}^{+}$ 必须是截断后的那个，否则下一轮的惯性项与实际位移不一致。

图 15.20是二维 Rastrigin 函数上 24 个粒子的一次运行，三幅分别是第 $0, 8, 60$ 轮的位置。第 8 轮粒子已聚向原点附近，第 60 轮已基本聚集，这次最好代价约为 2×10^{-5}。

15.1 搜索问题
15.2 模拟退火
15.3 演化策略
15.4 遗传算法
15.5 粒子群
15.5.1 个人与群体记忆
15.5.2 速度与位置更新
15.5.3 移动尺度与停滞
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

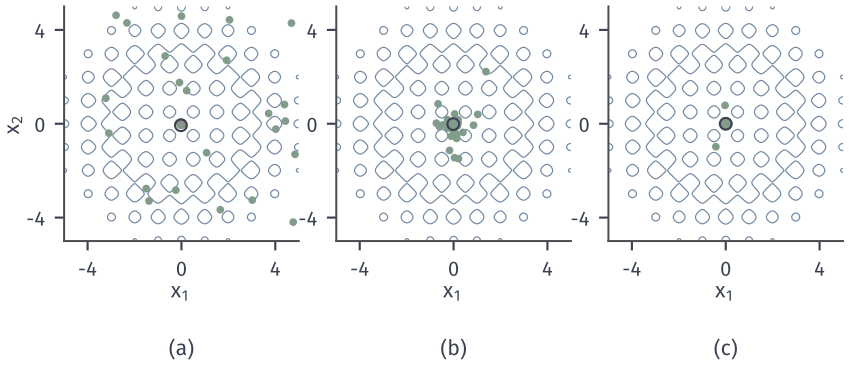


图 15.20 二维 Rastrigin 函数上的粒子群，$N = 24$，全局共享，带惯性权重 $\omega = 0.7298$，$c_1 = c_2 = 1.496$，$v_{\max} = 2$，同步更新，种子固定。(a)(b)(c) 分别是第 $0, 8, 60$ 轮的粒子位置（绿点），蓝线是等高线 $f = 30$，深色圆圈是当前的全局最好记忆，红点是全局最小点。

15.5.3 移动尺度与停滞

式 (15.39)没有任何东西让速度变小。这一小节的问题是：什么控制粒子的移动尺度，粒子群停止移动时又说明了什么？

为什么要给速度加阻尼 把问题简化。只看一维，记忆固定在 $p = g = 0$，把随机量换成常数，记 $\varphi = c_1 r_1 + c_2 r_2$。在旧速度前面乘上一个系数 ω（称为惯性权重），更新变成

$$v^+ = \omega v - \varphi x, \qquad x^+ = x + v^+. \tag{15.40}$$

式 (15.39)对应 $\omega = 1$。

定理 15.6 确定性粒子的稳定条件 递推 (15.40)对任意初值都有 $x^{(t)} \to 0$，$v^{(t)} \to 0$，当且仅当

$$|\omega| < 1, \qquad 0 < \varphi < 2 + 2\omega. \tag{15.41}$$

证明 把 v^+ 代入第二式，$x^+ = (1 - \varphi)x + \omega v$，于是

$$\begin{bmatrix} x^+ \\ v^+ \end{bmatrix} = \boldsymbol{M} \begin{bmatrix} x \\ v \end{bmatrix}, \qquad \boldsymbol{M} = \begin{bmatrix} 1 - \varphi & \omega \\ -\varphi & \omega \end{bmatrix}.$$

线性递推对任意初值收敛到零，当且仅当 $\boldsymbol{M}$ 的两个特征值模都小于 1。

$\boldsymbol{M}$ 的迹是 $1-\varphi+\omega$，行列式是 $\omega(1-\varphi)+\omega\varphi=\omega$，特征多项式为

$$\chi(z)=z^2-(1-\varphi+\omega)z+\omega.$$

先计算两个端点的值：

$$\chi(1)=\varphi,\qquad \chi(-1)=2+2\omega-\varphi.$$

两根为实数时，两根都在 $(-1,1)$ 内，当且仅当 $\chi(1)>0$，$\chi(-1)>0$，且两根之积的绝对值小于 1，这三条合起来正是式 (15.41)。

两根为共轭复数时，$\omega>0$，模的平方等于乘积 ω，所以模小于 1 当且仅当 $\omega<1$。此时判别式为负，给出

$$|1-\varphi+\omega|<2\sqrt{\omega}\le 1+\omega,$$

这就是 $0<\varphi<2+2\omega$，所以它自动成立。两种情形合起来，即得结论。 ■

$\omega=1$ 时行列式为 1，两个特征值的模乘积为 1，不可能都小于 1，所以原始的式 (15.39)没有衰减。图 15.21(a) 中 $\omega=1$，$\varphi=1.5$ 的轨迹一直等幅振荡；$\omega=0.7$ 时振荡衰减，45 步后已接近零。

这是把随机量换成常数后的结论，真实的 φ 每轮变化，乘积的稳定性与平均值的稳定性并不相同，定理只用来解释阻尼的作用。它说明了实践中必须做一件事：要么加 $v_{\max}$，要么取 $\omega<1$，否则粒子会越飞越散。

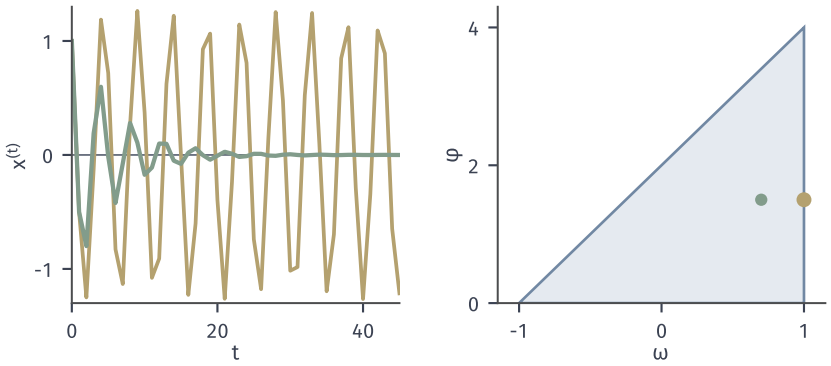


图 15.21 确定性粒子 (15.40)，记忆在原点，$x^{(0)}=1$，$v^{(0)}=0$。(a)$\varphi=1.5$，黄线 $\omega=1$，绿线 $\omega=0.7$。(b) 蓝色三角形是稳定区域 (15.41)，两个点对应 (a) 中的两组参数，黄点位于边界上。

15.1 搜索问题
15.2 模拟退火
15.3 演化策略
15.4 遗传算法
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

三个控制量 表 15.7比较影响移动尺度和信息传播的三个量。它们的合适取值依赖问题和预算。

表 15.7 粒子群的三个控制量。

控制量	增大时	过度时
$v_{\max}$	允许跳得更远	粒子飞出搜索区域
c_1, c_2	向记忆靠拢更用力	振荡，越过记忆点
邻域大小	信息传播更快	全群过早聚到一处

越界的处理 粒子飞出搜索区域 $[\ell_j, u_j]$ 时，位置和速度都要处理。常用的做法是把位置截断到边界并把该分量速度置零，或者把位置反射回来并反转速度分量。

只截断位置、保留原速度是不行的：下一步粒子会继续往外冲，每一轮都贴在边界上。不管用哪一种，都要保证下一轮的 $\boldsymbol{v}$ 与实际位移一致，这一点和速度限幅相同。第 15.6节会说明，这些处理也改变了搜索的分布。

停滞 考虑这样的状态：全体粒子都位于同一点 $\boldsymbol{x}^\circ$，$\boldsymbol{p}_i = \boldsymbol{g}_i = \boldsymbol{x}^\circ$，$\boldsymbol{v}_i = \boldsymbol{0}$。代入式 (15.39)，两个差都是零，旧速度也是零，于是不论 $\boldsymbol{r}_1, \boldsymbol{r}_2$ 取什么值，

$$\boldsymbol{v}_i^{+} = \boldsymbol{0}, \qquad \boldsymbol{x}_i^{+} = \boldsymbol{x}^\circ.$$

算法从此不再移动。

这个 $\boldsymbol{x}^\circ$ 可以是任何点。比如在 $f = \frac{1}{2}(x_1^2 + 9x_2^2)$ 上，$\boldsymbol{x}^\circ = (1, 1)$ 的梯度是 $(1, 9)$，它连驻点都不是。所以粒子聚在一起、速度趋于零或者记录长期不变，都只是搜索过程的描述，不是最优性的证明。

实际运行中粒子不一定精确聚在一点，但速度变小后移动的尺度已不足以发现更好的位置，效果相同。常用的补救是重新分散一部分粒子，同时保留历史最好记录。

15.6 约束处理

前面几节的手算例子已经遇到了不可行的候选：背包问题里超重的串，排列交叉产生的重复元素，粒子飞出区域。这就需要回答：候选不可行时有哪些处理方式，每种方式实际上交出了什么解，又对搜索分布有什么影响？

先判断可行 处理之前要能回答“这个候选在不在 $\boldsymbol{C}$ 里”。问题 (15.1)的 $\boldsymbol{C}$ 通常由判定条件给出：盒约束逐分量比较上下界，排列检查元素是否恰好各出现一次，背包约束把重量加起来和容量比较。

如果判定本身需要昂贵的模拟，每次判定也要计入预算。若只有 f 的评价能告诉我们是否可行，可行性就成了评价信息的一部分。

直接在可行集中产生候选 第一种方式是让操作本身不产生不可行的候选：排列上用交换和顺序交叉，盒内均匀初始化。这是最干净的做法，所有评价都用在可行候选上，不需要额外的规则。它的限制是这样的操作不总存在，一般的约束集合上没有简单的抽样办法。

拒绝 第二种方式是把不可行提议直接丢弃，就当没发生，等价于把不可行候选的代价设为 $+\infty$。模拟退火中，拒绝后留在原地，提议的对称性不受影响，定理 15.1的结论在 $\boldsymbol{C}$ 上仍然成立，平稳分布是限制在可行集上的 Gibbs 分布。

代价是可行集很小时大部分提议都浪费了，并且可行集不连通时，由邻域提议连接起来的图可能分成几块，算法走不到另一块。是否花费评价次数取决于是否在判定前做函数评价，这一点要照实计入。

修复 第三种方式是把不可行候选映射成一个可行候选，再评价。盒约束常用的是截断和反射；背包问题可以按价值密度 v_j/w_j 从低到高去掉物品，直到重量合格。

用遗传算法一节的不可行串 110110 演示。选中的物品是 $1,2,4,5$，价值密度依次是 3，1.67，1.29，1.2。去掉第 5 件后总重 12，不超容量，得到 110100，$f=-20$。

这时要明确记录什么。评价的是修复后的 110100，交出去的、记入最好记录的也必须是 110100，而不是原来的串。种群中可以存修复后的串，也可以存原串但使用修复后的评价，两种规则都可以，但要事先选定。

排列也可以修复。遗传算法一节非法的 12524 里元素 2 重复、元素 3 缺失，把第二次出现的 2 改成 3，得到合法排列 12534。修复规则不唯一，用哪条规则也要写明。

修复会改变搜索分布 修复不是无害的。图 15.22(a) 是一维的例子，当前点 $x=0.1$，提议 $\mathcal{N}(0.1,0.3^2)$，可行集为 $[0,1]$。落到区间外的概率约 0.37。截断把这些概率全部堆到边界 0 这一点，形成一个集中的质量；反射把区间外的部分折回区间内，密度连续；拒绝则把这部分质量留在当前点。

对称性是否保留是关键。反射后的提议密度是

$$\tilde{q}(x,y)=\sum_{k\in\mathbb{Z}}\big[\phi(y-x+2k)+\phi(y+x+2k)\big],$$

其中 ϕ 是 $\mathcal{N}(0, 0.3^2)$ 的密度。它关于 x, y 对称，所以模拟退火可以沿用式 (15.6)。截断不具有这个性质。

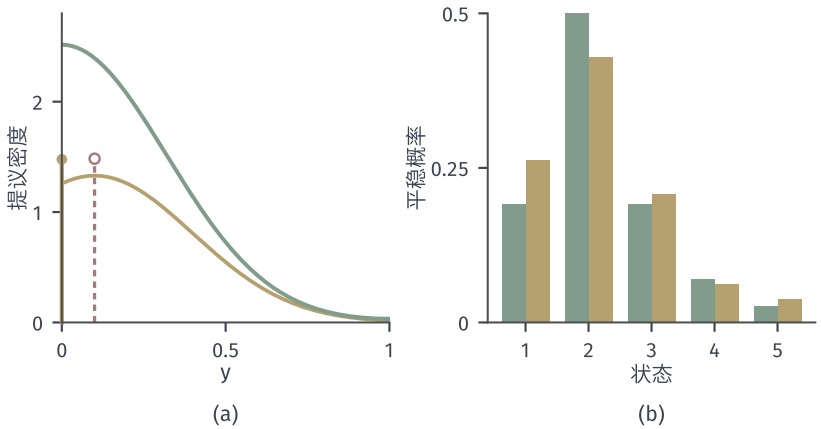


图 15.22 修复对分布的影响。(a) 从 $x = 0.1$ 出发的提议 $\mathcal{N}(0.1, 0.3^2)$ 在 $[0, 1]$ 上的三种处理：黄线是截断后区间内的密度，黄色竖线是截断堆积在 0 处的质量（高度为质量的 4 倍）；绿线是反射后的密度；红色虚线是拒绝时留在 $x = 0.1$ 的质量（同样放大 4 倍）。(b) 五状态链的平稳分布，绿柱为 Gibbs 分布，黄柱是用截断提议而未修正接受概率时的实际平稳分布。

用离散的例子算一下。状态 $\{1, \ldots, 5\}$，代价 $f = (1, 0, 1, 2, 3)$，$T = 1$。提议从 $\{-2, -1, +1, +2\}$ 等概率选步，超出范围就截断到端点。从 2 往左：-1 到 1，-2 截断也到 1，所以

$$q(2, 1) = \frac{1}{2}, \qquad q(1, 2) = \frac{1}{4},$$

提议不再对称。

仍用式 (15.6)，实际的平稳分布约为 $(0.262, 0.430, 0.208, 0.063, 0.037)$，而目标的 Gibbs 分布约为 $(0.192, 0.521, 0.192, 0.070, 0.026)$，见图 15.22(b)。最优状态 $x = 2$ 的概率从 0.521 掉到 0.430，边界状态的概率被抬高了。

要恢复 Gibbs 分布，须改用式 (15.10)的修正接受概率。因此模拟退火一旦带修复，就要重新核对提议与接受规则，第 15.2.2节的定理也不能直接引用。遗传算法、粒子群没有平稳分布的目标，修复的影响表现为搜索偏向边界。

惩罚评价 第四种方式是把违反量折算成代价。设违反量 $V(\boldsymbol{x}) \geq 0, V(\boldsymbol{x}) = 0$ 当且仅当可行，搜索时比较

$$f_\rho(\boldsymbol{x}) = f(\boldsymbol{x}) + \rho V(\boldsymbol{x}), \qquad \rho > 0. \tag{15.42}$$

15.1 搜索问题
15.2 模拟退火
15.3 演化策略
15.4 遗传算法
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.7.1 候选比较
15.7.2 历史最好解的复核
15.8 结果评价
15.9 本章小结

系数要足够大才有用。背包问题中 V 取超重量，串 110110 的 $f=-26$，$V=2$。取 $\rho=1$，$f_1=-24$，低于最优可行解的 -23，搜索会认为这个不可行的串是最好的。取 $\rho=10$ 时是 -6，它就排到了后面。

但 ρ 过大时，惩罚值的量级盖过 f 的差别，可行边界附近的比较失去区分度。这一取舍的系统讨论见第 22章。

无论 ρ 取多少，最好记录都要按式 (15.5)只在可行候选上更新。交出的结果若 $V>0$，就要明确说明，不能和可行解的代价放在一起比较。

四种方式的比较 表 15.8汇总了各种方式，重点是实际返回的解。

表 15.8 约束处理方式的比较。

方式	返回的解	主要风险
可行内生成	原候选	适用的集合有限
拒绝	原候选	浪费提议，可行集分块
修复	修复后的候选	改变搜索分布
惩罚	原候选，须核查可行性	系数不当，交出不可行解

这些都是搜索算法层面的工程处理，只回答“候选不可行时算法怎么办”。约束的最优性条件、乘子和一般的约束算法由第 17章起的第六部分承担。

15.7 含噪评价

到目前为止，读数都等于真实代价。如果每次评价带有噪声，如式 (15.4)，同一个候选评价两次也会得到不同的数。噪声影响了算法的哪些环节，最好记录的含义变成了什么，额外的评价应当花在哪里？

噪声影响三个环节 先明确优化的对象。本节设读数误差 ε 的均值为零，要最小化的是期望代价 $f(\boldsymbol{x})=\mathbb{E}[\tilde{f}(\boldsymbol{x})]$；如果关心的是分位数或最坏情形，要先改定目标。这也说明，第 15.2.2节的定理和第 15.3.2节的单调性都是针对精确代价的，不能直接用到含噪读数上。

第一个受影响的是**接受**。设真实上坡量为 2，$T=0.5$，无噪声时接受概率为 $\mathrm{e}^{-4}\approx 0.018$。若两次读数的误差各自服从 $\mathcal{N}(0,1)$，接受概率的平均值变成约 0.157，是原来的八倍多。噪声的效果相当于抬高了温度。

第二个是**排序**：种群中的名次可能和真实好坏相反，选择压力被噪声稀释。第三个是**最好记录**，这是最隐蔽的，下面专门讨论。

15.1 搜索问题
15.2 模拟退火
15.3 演化策略
15.4 遗传算法
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.7.1 候选比较
15.7.2 历史最好解的复核
15.8 结果评价
15.9 本章小结

最低读数偏向有利噪声 设有 N 个候选，真实代价都是 0，读数相互独立，服从 $\mathcal{N}(0,1)$。算法把读数最低的那个当作最好解，它的读数是 N 个标准正态变量的最小值，期望是负的。

$N=2$ 时可以手算。由 $\min(a,b)=\frac{1}{2}(a+b-|a-b|)$，两个读数 Z_1,Z_2 的最小值的期望是

$$\mathbb{E}\min(Z_1,Z_2)=-\frac{1}{2}\mathbb{E}|Z_1-Z_2|.$$

$Z_1-Z_2\sim\mathcal{N}(0,2)$，$\mathbb{E}|Z|=\sqrt{2/\pi}$，于是

$$\mathbb{E}\min(Z_1,Z_2)=-\frac{1}{2}\cdot\sqrt{2}\cdot\sqrt{\frac{2}{\pi}}=-\frac{1}{\sqrt{\pi}}\approx-0.564.$$

N 增大，这个偏差继续变大。图 15.23(a) 显示 $N=1000$ 时最低读数的均值约为 -3.24，虽然所有候选的真实代价都是 0。比较的次数越多，“最好”的读数越乐观。

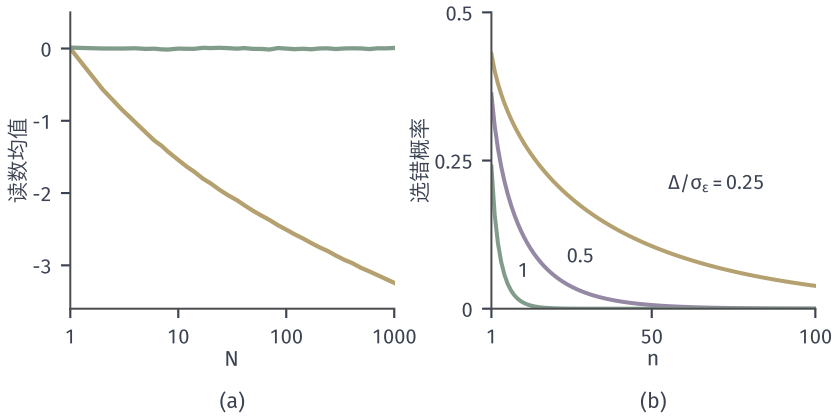


图 15.23 噪声下的选择。(a)N 个真实代价都为 0 的候选，噪声服从 $\mathcal{N}(0,1)$，黄线是最低读数的均值，绿线是对选出者重新读一次的均值，由 20000 次抽样估计。(b) 两候选真实差为 Δ，噪声标准差为 σ_ε，各读 n 次后按样本均值选错的概率，按式 (15.43)计算。

15.7.1 候选比较

两个候选的读数不同，这个差别是真的吗？这一小节讨论要读多少次才能下判断，以及读数应当分给谁。

重复读数 设候选 $\boldsymbol{a}$ 的真实代价比 $\boldsymbol{b}$ 低 $\Delta>0$。每个候选独立读 n 次，取样本均值。读数的噪声方差都是 σ_ε^2 时，样本均值之差的方差是 $2\sigma_\varepsilon^2/n$。

样本均值之差的标准差按 $1/\sqrt{n}$ 下降，而要分辨的真实差 Δ 不变，所以 Δ 越小，需要的读数越多。

定理 15.7　两候选比较的错误概率　设两候选的读数相互独立，方差都是 σ_ε^2，真实代价差为 $\Delta>0$，各读 n 次后选样本均值较低者。若噪声服从高斯分布，选错的概率为

$$\mathbb{P}(\text{选错})=\Phi\!\left(-\frac{\Delta}{\sigma_\varepsilon}\sqrt{\frac{n}{2}}\right), \tag{15.43}$$

其中 Φ 是标准正态分布函数。若只假定方差有限，则有

$$\mathbb{P}(\text{选错})\le\frac{2\sigma_\varepsilon^2}{n\Delta^2}. \tag{15.44}$$

证明　记 $\bar a,\bar b$ 为两个样本均值，令 $W=\bar a-\bar b+\Delta$，W 的均值为 0，方差为 $2\sigma_\varepsilon^2/n$。选错即 $\bar a\ge\bar b$，也就是 $W\ge\Delta$。

高斯情形下 $W\sim\mathcal{N}(0,2\sigma_\varepsilon^2/n)$，标准化后即得式 (15.43)。方差有限时，由 Chebyshev 不等式，

$$\mathbb{P}(W\ge\Delta)\le\mathbb{P}(|W|\ge\Delta)\le\frac{2\sigma_\varepsilon^2}{n\Delta^2}.$$

■

图 15.23(b) 是式 (15.43)。$\Delta/\sigma_\varepsilon=1$ 时，一次读数选错的概率约为 0.24，$n=4$ 时约为 0.079，$n=16$ 时约为 0.002。$\Delta/\sigma_\varepsilon=0.5$ 时要 $n=16$ 才降到 0.079，差减半，读数要多四倍。这也就是说，n 按 $(\sigma_\varepsilon/\Delta)^2$ 增长。

方差未知时要用样本方差，置信水平还要计入同时比较的次数，这些统计保证的条件和推导可参考卷八第 4 章“有限样本的误差上界”。

把预算分给难分辨的候选　候选的差别悬殊时，一两次读数就够分辨；差别小的，才值得多读。因此比全体平均分配读数更省的安排是：先给每个候选少量读数，计算均值和不确定性区间，淘汰区间明显落后的候选，把后续读数分给仍难分辨的那些。

这里要区分两种错误。比较误差是已见候选之间排错了名次；覆盖不足是更好的点根本没被评价过。多读几次已见的候选，只能减少前者。复核已见候选不能证明不存在更优的未见点。用于复核的读数和探索新候选竞争同一份预算，两者的分配要依问题决定。

15.1 搜索问题
15.2 模拟退火
15.3 演化策略
15.4 遗传算法
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.7.1 候选比较
15.7.2 历史最好解的复核
15.8 结果评价
15.8.1 停止条件
15.8.2 预算与重复运行
15.9 本章小结

15.7.2 历史最好解的复核

上面看到最低读数偏向有利噪声。这一小节的问题是：对选出来的候选还能相信什么，要怎样复核？

选中之后重新评价 式 (15.5)的记录是一次选择的结果，所以这个读数带偏。对选出的候选**用新的独立读数**重新评价，得到的就是无偏的估计。

原因是：选择只依赖旧的读数，新的噪声与选择无关。设选中的候选是 $\hat{\boldsymbol{x}}$，给定 $\hat{\boldsymbol{x}}$ 的条件下，新读数的条件期望是 $f(\hat{\boldsymbol{x}})$，所以

$$\mathbb{E}\big[\tilde{f}_{\text{new}}(\hat{\boldsymbol{x}}) \mid \hat{\boldsymbol{x}}\big] = f(\hat{\boldsymbol{x}}). \tag{15.45}$$

图 15.23(a) 的绿线正是这一点，重新读一次的均值稳定在真实值 0 附近。

条件是新读数必须与用于选择的读数独立。把旧读数和新读数平均，偏差只是减小，并不消失。若一批复核读数又用来在多个候选中再选一次，新的选择偏差又产生了，要再留一批读数来做最终的估计。

新旧记录的比较 旧记录的读数是经过多次比较选出来的最小值，新候选只有一次读数，两者并不能等量比较。$(1+1)$ 策略一旦遇到一次特别幸运的读数，后代的一次读数几乎都比不过它，这个亲代就长期占位，算法看起来“收敛”了，实际只是被一次噪声卡住。

常用的修正是每一代重新评价亲代，或者让记录中的候选累积多次读数后再参与比较。这些额外的评价都要计入预算，代价是每代评价数增加。

要记录什么 搜索过程实际使用的选解规则要原样记录：是取最低的单次读数，还是取重复读数的最低均值，还是另留一批独立读数做最后的裁决。

报告结果时也要说清每个数字的来源。“最好值”如果是搜索过程中的最低读数，就是偏乐观的；如果来自独立的复核读数，才能作为对 $f(\hat{\boldsymbol{x}})$ 的估计。样本复用省评价次数，但信息依赖也要一并交代。

15.8 结果评价

前面每种方法都给出了手算和几幅运行图。于是要问：两种随机搜索的结果怎样比才算数，一次运行结束时能下什么结论？要把三类说法分开：有限预算内得到了什么，长期运行有什么极限性质，以及能否验证结果确实接近最优。

15.1 搜索问题
15.2 模拟退火
15.3 演化策略
15.4 遗传算法
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.8.1 停止条件
15.8.2 预算与重复运行
15.9 本章小结

15.8.1 停止条件

算法要在某一刻停下来。这一小节的问题是：各种停止规则分别支持什么结论？

四种规则 **评价次数上限**在用完 B 次后停止，这是最容易比较的一种。**时间上限**在规定的墙钟时间后停止，它依赖机器和实现。**目标阈值**在 $f_{\text{best}} \le f_{\text{target}}$ 时停止，要有事先给定的阈值。**停滞规则**在连续若干轮没有改善时停止。

停滞规则只描述已观察到的过程 图 15.24(c) 是五维 Rastrigin 问题上遗传算法的一次运行。最好值从第 300 次评价前后开始，在 10.28 上停了 500 多次评价，接着又下降，最后约为 0.02。若规则是“连续 500 次评价没有改善就停”，这次运行就会在那段平台上结束，报告 10.28。

停滞规则说的是最近没有发现更好的点，不代表不存在更好的点。它是预算的管理手段，不是最优性的判据。分布的 σ 变小、粒子聚集、种群趋同也都一样。

有下界时报告间隙 能证明 $\ell \le f^\star$ 时，可行解 $\hat{\boldsymbol{x}}$ 的目标差不超过 $f(\hat{\boldsymbol{x}}) - \ell$，这是可以验证的结论，第 1章讨论过这种夹逼。

第 15.4节的背包问题就是如此：把物品按价值密度排序，允许最后一件取一部分，得到的分数背包最优值是原问题价值的上界，也就是代价的下界。那里的六件物品按价值密度排序，取第 $1,2,3$ 件用去重量 11，再取第 4 件的 $4/7$，分数解的总价值为 $19 + \frac{4}{7}\times 9 \approx 24.14$。价值都是整数，所以 $f^\star \ge -24$，最好可行解 -23 与最优值至多差 1，这是不依赖搜索过程的结论。

大多数黑箱问题没有可靠的下界。这时老实的报告是：最好可行值是多少，用了多少次评价。不能写“达到全局最优”，因为最优值未知，而 $f(\hat{\boldsymbol{x}}) - f^\star$ 根本无从计算。

15.8.2 预算与重复运行

停下来以后要比较。这一小节的问题是：不同算法的成本怎样折算到同一单位，一次运行不够时要比较什么？

统一的成本单位 不同算法的“一轮”含义不同：退火的一轮是一次评价，CMA-ES 的一代是 λ 次，粒子群的一轮是 N 次。按轮数比较没有意义，必须换算成实际的函数调用次数。表 15.9列出需要计入的内容。

表 15.9 成本的记录。第一类按评价次数统一累计，第二类另行报告。

类别	项目
函数调用	种群评价、退火尝试、修复后的评价 重复读数、最好解复核、重启 温度标定等试探性评价
内部运算	CMA-ES 的矩阵分解、排序
存储	种群、协方差矩阵、记忆位置
并行	群体通信、同步等待的时间

评价便宜时，内部运算可能反而占主导，这时只数评价次数是不够的；评价昂贵时，内部运算可以忽略。两者都要记下，分别报告。

结果是一个分布 这些算法是随机的，一次运行的结果只是一个样本。比较时要固定问题、固定初始条件的抽取规则和预算，做若干次独立运行，比较结果的分布，例如中位数和四分位数。用一次最好的运行代表一个方法，或者挑选种子，都没有意义。

比较实验 图 15.24比较五种做法。问题是五维 Rastrigin 函数，搜索区域为 $[-5.12, 5.12]^5$，统一预算 $B = 10000$，每种方法独立运行 41 次。表 15.10给出结束时的结果，“达标”指最好值不超过 3。

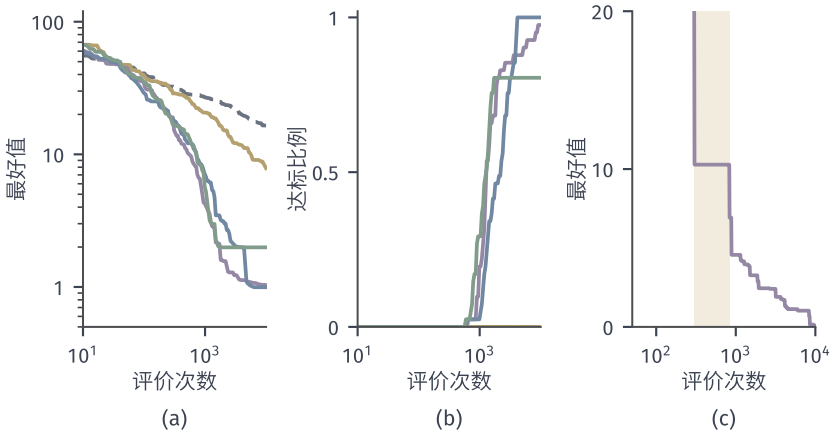


图 15.24 五维 Rastrigin 函数上的比较，$B = 10000$，每种方法 41 次独立运行。灰色虚线为均匀随机抽样，黄线为模拟退火，紫线为实数编码遗传算法，蓝线为粒子群，绿线为 CMA-ES。(a) 最好值中位数随评价次数的变化。(b) 最好值不超过 3 的运行所占比例。(c) 遗传算法一次运行的最好值，浅黄区间是一段长约 530 次评价没有改善的平台。

15.1 搜索问题
15.2 模拟退火
15.3 演化策略
15.4 遗传算法
15.5 粒子群
15.6 约束处理
15.7 含噪评价
15.8 结果评价
15.9 本章小结

表 15.10 $B = 10000$ 时的结果（41 次运行）。

方法	中位数	上下四分位	达标比例
均匀随机抽样	16.49	13.84–18.49	0
模拟退火	7.86	5.69–10.35	0
遗传算法	1.03	0.11–2.00	0.98
粒子群	0.99	0.99–1.28	1.00
CMA-ES	1.99	0.99–2.98	0.80

这张表说明什么、不说明什么要说清楚。在这个问题、这组未专门调参的设置、这个预算下，三种基于群体或分布的方法达到了相近的量级，均匀抽样和这里的单点退火明显落后。

它不说明任何方法“更好”。退火换一组温度和提议尺度，结果可能大幅改变；CMA-ES 此时已经收敛，后段的预算没有用上，加上重启可能改善；换一个问题，排序也可能颠倒。

图 15.24(b) 的曲线比一个终点数字更有信息：它回答了“要达到这个目标需要多少次评价”，三种方法都在约 10^3 次评价附近开始达标，CMA-ES 的比例在约 0.8 处走平。

三类结论 表 15.11把本章的结论按能够支持什么说法分类。写报告时，要清楚自己手里的结论属于哪一类。

表 15.11 三类结论。

类别	例子与含义
有限预算的结果	中位数、达标比例：只对所测的设置成立
长期收敛结论	对数降温定理：是极限，并依赖模型条件
可验证的证书	下界与间隙：与算法如何运行无关

15.9 本章小结

本章讨论只能评价候选时怎样组织搜索。局部改善会停在低谷，这在有限状态的双谷代价和二维多峰函数上都看得很清楚。要越过障碍，算法必须做眼前并不划算的事，四类方法的差别在于保存什么、用什么规则更新。

模拟退火控制单个状态的接受。对称提议下，固定温度的接受规则使 Gibbs 分布平稳。全局收敛定理只在有限状态、提议连通且 $c \geq d^\star$ 的对数降温下成立，而且是概率的极限。实际的几何降温按有限预算的结果评价，温度要与代价的尺度匹配。

演化策略适应变异分布。保留亲代使最好值不增，整代替换允许当前值上升。CMA-ES 用选中后代的加权平均移动中心，用路径和选中位移更新协方差，用标准化路径的长度调整尺度。搜索协方差不是 Hessian，也不无条件等于 Hessian 的逆。高斯搜索分布的均值梯度与第 14章的平滑梯度估计重合，排序效用则改变了目标。

遗传算法组织编码的重组与替换。编码决定什么叫邻近，排列上要用保持排列的算子，比例选择要先把代价转换为非负权重。交叉重组已有片段，变异引入新内容，没有变异时种群会完全趋同。

粒子群利用个人和邻域的记忆移动候选。记忆的差不是梯度，没有阻尼时确定性粒子不衰减，速度限幅后要按修正后的速度计算位移。粒子聚在一起不是最优性的证明。

各种方法要落在同一套可行性、评价信息和预算的记账上。不可行候选的处理决定了实际返回的解，修复会改变搜索分布，模拟退火须重新核对接受规则。含噪读数下最低读数偏向有利噪声，对选出的候选要用独立的新读数复核。比较方法时按实际函数调用统一预算，比较多次独立运行的结果分布。

搜索取得改善，不等于找到了全局最优。能给出下界时报告间隙，否则如实报告最好可行值和所用的预算。下一章讨论评价更昂贵的情形，用概率代理模型决定下一次评价的位置。

16.1 昂贵黑箱问题
16.1.1 评价点与推荐解
16.1.2 概率模型的作用
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

第 16 章

贝叶斯优化

一次流体仿真要跑四个小时，它有一个需要调节的参数，我们希望输出误差尽量小。仿真程序是一个不透明的黑箱，给它一个参数，它还回一个数，不给导数。这周的算力只够运行六次。第六次运行结束时必须交出一个参数值，往后就按它使用。六次机会应该怎么花？

第 14章用函数值差分构造局部方向，第 15章靠大量候选的提议和淘汰探索解空间，这两条路都假定评价次数可以比较多。评价极贵时，每一次评价之后都值得停下来，把已有读数全部用上，认真想一想下一次该放在哪里。**贝叶斯优化**（Bayesian optimization）就是把这件事组织成计算的办法：用已完成的读数建立一个带不确定性的概率模型，再按潜在收益和不确定性决定下一次评价。

全章用一个一维仿真例子贯穿。我们先说清问题里“评价点”和“最终推荐”的区别，再建立高斯过程这个概率模型，然后比较几种把模型变成选点分数的规则，把它们接成一个完整的循环。之后依次放宽理想假设，讨论读数有噪声、约束也要试验才知道、多个试验同时运行三种情形。最后回答预算怎样核算，最终结果怎样评价，以及哪些结论有理论保证、在什么条件下成立。

16.1 昂贵黑箱问题

只有 T 次昂贵评价时，优化问题应当怎样提？设搜索域 $\boldsymbol{C} \subseteq \mathbb{R}^n$ 已知，目标 $f : \boldsymbol{C} \to \mathbb{R}$ 的表达式未知，要解的是

$$\min_{\boldsymbol{x} \in \boldsymbol{C}} \; f(\boldsymbol{x}), \tag{16.1}$$

其中每次只能选一个 $\boldsymbol{x}$，付出一次运行的代价，读到一个函数值。这类只能通过读数了解目标的问题称为**黑箱优化**（black-box optimization）。

与前面各章不同，这里最先固定的不是精度，而是预算：允许多少次评价，或者总共多少运行时间。问题随之变成“这 T 次机会怎样分配”。机

16.1 昂贵黑箱问题
16.1.1 评价点与推荐解
16.1.2 概率模型的作用
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

会要分给两类地方：看起来有希望的区域，以及几乎一无所知的区域。只去前者可能错过别处更深的谷，只去后者又用不上已经学到的东西。

贯穿全章的例子 设仿真参数 x 在 $\boldsymbol{C} = [0, 8]$ 内取值，输出误差 $f(x)$ 已作标准化，负值表示比基准好，预算 $T = 6$。表 16.1列出整数位置上的读数。真实计算时这张表并不存在，算法只会知道被评价过的那几列；把它写出来是为了让后面的每一步都可以核对。

表 16.1 贯穿例的整数位置读数。函数 f 是过这九个点的自然三次样条，只作为教学假设，算法不知道它。

x	0	1	2	3	4	5	6	7	8
$f(x)$	0.9	0.2	−0.5	0.1	0.7	0.3	−1.0	−0.3	0.8

这个函数有两个谷，一个在 $x = 2$ 附近，另一个在 $x = 6$ 附近，后者更深。样条的最小值约为 -1.029，在 $x \approx 6.13$ 处取得。

16.1.1 评价点与推荐解

六次评价结束后要交出一个答案。答案未必是读数最好的那次，也未必是评价过的点。为了不把两件事混在一起，需要分开两个角色：评价点用来收集信息，推荐解用来实际采用。

图 16.1是后面算法在贯穿例上实际走出的六次评价，数字是评价的先后。第 4 次去了 $x = 8$，读数 0.8 很差，从目标值看是一次失败。可是它告诉我们右端不值得再投入，这对后面的判断有用。第 5 次在 $x = 6$ 读到 -1.0，于是最终推荐 $\hat{x}_6 = 6$。第 6 次在 $x = 0$ 的读数 0.9 又差得多，但这并不影响推荐，因为推荐解不需要是最后一次评价。

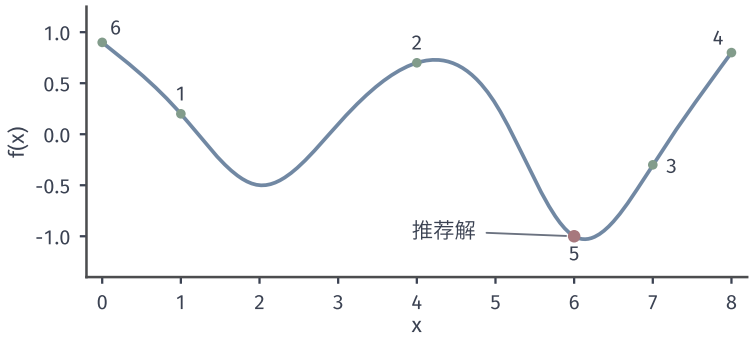


图 16.1 评价点与推荐解。蓝线是目标 f，绿点是六次评价，旁边的数字是评价顺序，红点是最终推荐。第 4 次和第 6 次的读数很差，它们的任务是收集信息，不是交付答案。

16.1 昂贵黑箱问题
16.1.1 评价点与推荐解
16.1.2 概率模型的作用
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

用数据集合记录当前已有的信息。设前 t 次评价的位置与读数为 $(\boldsymbol{x}_i, y_i)$，记

$$\mathcal{D}_t = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^{t}. \tag{16.2}$$

这里下标 i 表示第 i 次评价，因为后面总要同时引用多次评价的位置，所以本章把评价序号写在下标。

选点规则必须遵守时间次序：第 $t+1$ 个评价点只能依赖 $\mathcal{D}_t$，至多再加上与目标无关的随机数，不能用尚未返回的读数。图 16.2画出了这个次序。这条要求看似多余，实际很有约束力。比较不同方法时，若某个方法的超参数是用全部读数调好的，它在前几步就已用到了未来的信息，比较便不公平。

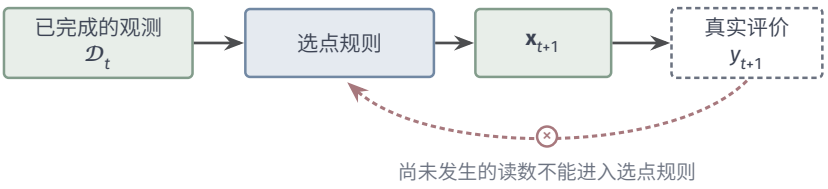


图 16.2 选点规则可以使用的信息。选点规则只读取已完成的观测 $\mathcal{D}_t$，下一次评价的读数 y_{t+1} 在选点之后才产生（虚线框），红色虚线表示这条信息通路不允许存在。

16.1.2 概率模型的作用

只有三个读数时，$x = 6$ 处的函数值是多少？我们不知道，但并非毫无看法：离读数近的地方函数值大概与读数接近，离得远的地方拿不准。要把“大概”和“拿不准”写成可以计算的东西，需要给未知的 f 配一个概率描述。

这里最容易误解的一点是，f 本身并不随机。仿真程序是确定的，同一个 x 每次算出同样的结果，只是我们不知道结果。概率描述的是我们的认识状态，不是目标的物理性质。做法是引入一个随机函数 F 作为模型，把 f 看成它可能的一种情形。在看到数据之前，F 的分布称为**先验**（prior）；把 $\mathcal{D}_t$ 作为条件之后，F 的分布称为**后验**（posterior）。

后验分布的变化，表示认识变了，不表示目标变了。可以把它想成一张还在绘制中的地形图：实地地形一直没动，测过的点清晰，没测过的地方模糊，每多测一点，图就清楚一些。这个比方有一处不准确：地形图的模糊只来自没测量，而概率模型的结论还依赖我们事先对地形光滑程度的假设，假设错了，图可能清晰却画错了。

图 16.3中的紫线是在 $x = 1, 4, 7$ 三个读数条件下，从模型里抽取的几条函数。它们都穿过三个读数，在读数之间各走各的路。蓝线是真实目标，只有一条，它在整个过程中不改变。浅蓝带是模型认为函数值大致所在的

范围，读数处收成一点，远离读数时变宽。下一次评价的放置，就要根据这种“哪里可能低、哪里还拿不准”的信息来定。

16.1 昂贵黑箱问题
16.2 概率代理
16.2.1 高斯过程先验
16.2.2 后验预测
16.2.3 模型设定
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

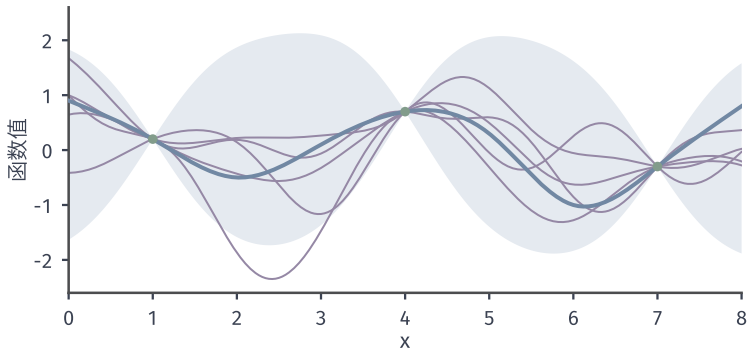


图 16.3 固定的目标与模型的多种可能。粗蓝线是真实目标 f，绿点是 $x = 1, 4, 7$ 的读数，细紫线是后验分布的五个样本，浅蓝带是后验均值上下各两倍标准差。五条紫线都与读数相符，它们的差异表示认识的不确定，不表示 f 在变化。

概率模型是本章区别于前两章的关键。三章都可以只用函数值，分工却在于用这些值做什么，表 16.2作了对比。也要注意，“贝叶斯”这个词不意味着算法每步都在抽签。后面的期望改进给定 $\mathcal{D}_t$ 后完全确定，只有 Thompson 采样这样的规则才主动使用随机数。

表 16.2 三种只用函数值的做法。

	用读数做什么	适合的评价预算
零阶随机优化	差分成局部方向	较多，随维数增长
随机搜索	更新搜索状态或分布	较多，候选大量淘汰
贝叶斯优化	建模后计算下次评价的价值	很少，每次都很贵

16.2 概率代理

怎样用一个读数更新没有被评价的位置的认识？这要求模型做到两件事，一是对每个候选点给出可能函数值的分布，二是说清不同位置之间怎样关联，否则一个位置的读数对其他位置不起作用。满足这两点、用来代替昂贵目标接受查询的模型，称为**概率代理**（probabilistic surrogate）。

本节以高斯过程为主说明这个接口。贝叶斯优化并不依赖高斯过程，只要模型能给出相应的预测分布，例如贝叶斯神经网络、树模型的集成，也可以代入后面的选点规则，只是计算的具体公式不同。

16.1 昂贵黑箱问题
16.2 概率代理
16.2.1 高斯过程先验
16.2.2 后验预测
16.2.3 模型设定
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

16.2.1 高斯过程先验

先看模型要表达的直觉：相近的参数，通常给出相近的仿真结果。这句话有两层意思。其一，单看一个位置，函数值可能的范围是一个分布。其二，两个位置离得越近，它们的函数值越同涨同落。用协方差描述第二层意思最直接，而最便于计算的联合分布是多元高斯分布。

定义 16.1　高斯过程　设 $m_0 : \boldsymbol{C} \to \mathbb{R}$，$k : \boldsymbol{C} \times \boldsymbol{C} \to \mathbb{R}$。若对任意有限个点 $\boldsymbol{x}_1, \dots, \boldsymbol{x}_n \in \boldsymbol{C}$，向量 $(F(\boldsymbol{x}_1), \dots, F(\boldsymbol{x}_n))^{\top}$ 都服从多元高斯分布，且

$$\mathbb{E}[F(\boldsymbol{x})] = m_0(\boldsymbol{x}), \qquad \operatorname{Cov}(F(\boldsymbol{x}), F(\boldsymbol{x}')) = k(\boldsymbol{x}, \boldsymbol{x}'), \tag{16.3}$$

就称随机函数 F 是以 m_0 为**均值函数**（mean function）、以 k 为**协方差核**（covariance kernel）的**高斯过程**（Gaussian process，GP）。

定义只谈有限个点，这正是它好用的地方。一次计算只会碰到有限个位置，手头需要的总是一个普通的多元高斯分布。

核 k 不能随便写。把几个位置的函数值作线性组合，方差必须非负。对任意实数 $a_1, \dots, a_n$，

$$0 \le \operatorname{Var}\Big(\sum_{i=1}^{n} a_i F(\boldsymbol{x}_i)\Big) = \sum_{i=1}^{n}\sum_{j=1}^{n} a_i a_j k(\boldsymbol{x}_i, \boldsymbol{x}_j) = \boldsymbol{a}^{\top} \boldsymbol{K} \boldsymbol{a},$$

其中 $\boldsymbol{K}$ 是元素为 $k(\boldsymbol{x}_i, \boldsymbol{x}_j)$ 的矩阵。所以 k 必须对称，且任意有限组点上的 $\boldsymbol{K}$ 都半正定。反过来，满足这两条的 k 配上任意均值函数，确实对应一个高斯过程，证明要用到有限维分布族的相容性与延拓定理，这里只使用结论。

贯穿例的核　本章取 $m_0 \equiv 0$，并取

$$k(x, x') = 2^{-(x - x')^2}. \tag{16.4}$$

它是常用的**平方指数核**（squared exponential kernel）$\exp(-(x-x')^2/(2\ell^2))$ 在 $\ell^2 = 1/(2\ln 2)$ 时的情形，$\ell \approx 0.85$。选这个数只是为了手算：间距 $1, 2, 3$ 的相关系数分别是 $1/2, 1/16, 1/512$。先验方差 $k(x, x) = 1$ 表示模型认为函数值大致在 ± 2 内，这与表 16.1的数量级相符。

取三个相邻位置 $x = 3, 4, 5$，核矩阵为

$$\boldsymbol{K} = \begin{bmatrix} 1 & 1/2 & 1/16 \\ 1/2 & 1 & 1/2 \\ 1/16 & 1/2 & 1 \end{bmatrix}.$$

16.1 昂贵黑箱问题
16.2 概率代理
16.2.1 高斯过程先验
16.2.2 后验预测
16.2.3 模型设定
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

三个顺序主子式依次为

$$1, \qquad \frac{3}{4}, \qquad \frac{135}{256},$$

全部为正，所以这个 $\boldsymbol{K}$ 正定。

核规定了模型愿意相信的变化尺度 参数 ℓ 称为长度尺度（length scale），它回答“隔多远的两个点就基本无关了”。图 16.4比较了三个取值。ℓ 小时相关性衰减快，先验样本频繁起伏；ℓ 大时样本缓慢变化。三条样本用的是同一组随机数，差别完全来自核。

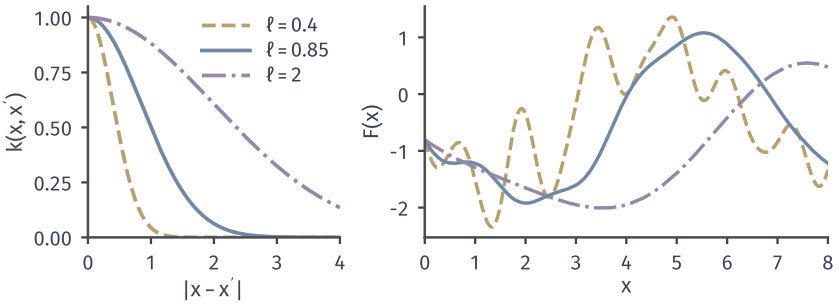


图 16.4 长度尺度的作用。(a) 平方指数核随距离的衰减，$\ell = 0.85$ 是贯穿例的取值。(b) 用同一组标准正态随机数生成的三条先验样本，线型与 (a) 对应。长度尺度越大，样本越缓慢。

所以核不只是计算工具，它是我们事先下的一个赌注。选了 ℓ，就等于声明目标不会比这个尺度变化得更快。这一声明可能错，第 16.2.3节专门讨论错了会怎样。

16.2.2 后验预测

先用两个位置看清更新是怎么发生的。考虑 $x = 3$ 和 $x = 4$，由式 (16.4)，

$$\begin{bmatrix} F(3) \\ F(4) \end{bmatrix} \sim N\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 1/2 \\ 1/2 & 1 \end{bmatrix} \right).$$

现在只评价 $x = 3$，无噪声地读到 $F(3) = 1$。关键是把 $F(4)$ 拆成“能由 $F(3)$ 解释的部分”和“剩余部分”：

$$F(4) = \tfrac{1}{2} F(3) + R.$$

系数 $1/2$ 的选法是让 R 与 $F(3)$ 不相关：

$$\operatorname{Cov}(R, F(3)) = \tfrac{1}{2} - \tfrac{1}{2} \cdot 1 = 0.$$

联合高斯时不相关就意味着独立，所以读到 $F(3)$ 不改变 R 的分布。R 的方差为

$$\mathrm{Var}(R) = 1 - 2 \cdot \tfrac{1}{2} \cdot \tfrac{1}{2} + \tfrac{1}{4} \cdot 1 = \tfrac{3}{4}.$$

代入 $F(3) = 1$，得到

$$F(4) \mid F(3) = 1 \;\sim\; N\big(\tfrac{1}{2}, \tfrac{3}{4}\big).$$

虽然没有评价 $x = 4$，这里的均值从 0 变成了 0.5，方差从 1 降到了 0.75。图 16.5中，(a) 的椭圆是联合分布的等高线，在 $F(3) = 1$ 处竖切一刀，得到 (b) 中的绿线。椭圆是斜的，切线才偏离中心；若相关系数为 0，椭圆不倾斜，切出来的分布就和先验一样，读数不传递任何信息。

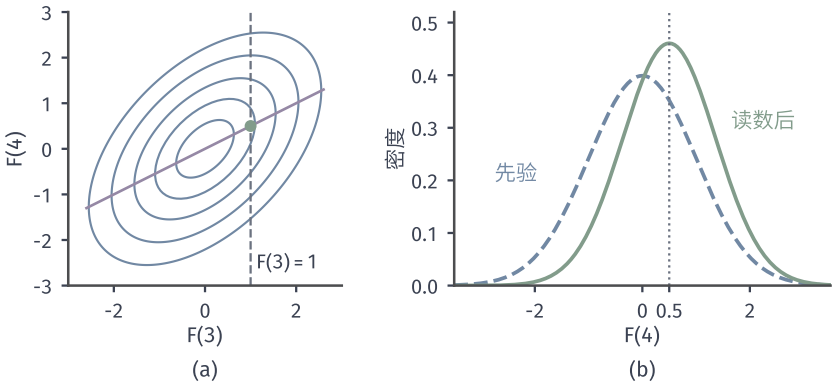


图 16.5 读数怎样传到相关的位置。(a) 蓝色椭圆是 $(F(3), F(4))$ 的联合分布等高线，相关系数 $1/2$，紫线是条件均值 $F(4) = F(3)/2$，竖虚线是读数 $F(3) = 1$，绿点是该读数下 $F(4)$ 的条件均值。(b) 蓝虚线是 $F(4)$ 的先验 $N(0, 1)$，绿线是读数后的 $N(1/2, 3/4)$。

一般情形只是把这种拆分写成矩阵。记 $\boldsymbol{K}_t$ 为 $t \times t$ 矩阵，元素是 $k(\boldsymbol{x}_i, \boldsymbol{x}_j)$；$\boldsymbol{k}_t(\boldsymbol{x})$ 是长度 t 的向量，第 i 个分量是 $k(\boldsymbol{x}, \boldsymbol{x}_i)$；$\boldsymbol{y}_t$ 是读数向量；$\boldsymbol{m}_{0,t}$ 是先验均值在各评价点处的取值。读数可能含噪，设 $y_i = F(\boldsymbol{x}_i) + \varepsilon_i$，$\varepsilon_i \sim N(0, \tau^2)$，彼此独立，且与 F 独立；$\tau = 0$ 表示无噪声。

定理 16.2 高斯过程的后验 设 F 是高斯过程，评价点固定，核与噪声参数已知，$\boldsymbol{A}_t = \boldsymbol{K}_t + \tau^2 \boldsymbol{I}$ 可逆。则给定 $\boldsymbol{y}_t$，F 仍是高斯过程，其后验均值与后验协方差为

$$m_t(\boldsymbol{x}) = m_0(\boldsymbol{x}) + \boldsymbol{k}_t(\boldsymbol{x})^{\top} \boldsymbol{A}_t^{-1} (\boldsymbol{y}_t - \boldsymbol{m}_{0,t}), \tag{16.5}$$

$$c_t(\boldsymbol{x}, \boldsymbol{x}') = k(\boldsymbol{x}, \boldsymbol{x}') - \boldsymbol{k}_t(\boldsymbol{x})^{\top} \boldsymbol{A}_t^{-1} \boldsymbol{k}_t(\boldsymbol{x}'). \tag{16.6}$$

特别地，记 $s_t^2(\boldsymbol{x}) = c_t(\boldsymbol{x},\boldsymbol{x})$，则

$$F(\boldsymbol{x}) \mid \mathcal{D}_t \sim N\big(m_t(\boldsymbol{x}), s_t^2(\boldsymbol{x})\big). \tag{16.7}$$

证明 取任意有限组候选点，F 在这些点与读数向量合起来是联合高斯的。对一个候选点 $\boldsymbol{x}$，令

$$\boldsymbol{a} = \boldsymbol{A}_t^{-1}\boldsymbol{k}_t(\boldsymbol{x}).$$

定义剩余量

$$R(\boldsymbol{x}) = F(\boldsymbol{x}) - m_0(\boldsymbol{x}) - \boldsymbol{a}^{\top}(\boldsymbol{y}_t - \boldsymbol{m}_{0,t}),$$

这里 $\boldsymbol{y}_t$ 理解为随机向量。

读数的协方差矩阵是 $\boldsymbol{A}_t$，$F(\boldsymbol{x})$ 与读数的协方差向量是 $\boldsymbol{k}_t(\boldsymbol{x})$，于是

$$\operatorname{Cov}(R(\boldsymbol{x}), \boldsymbol{y}_t) = \boldsymbol{k}_t(\boldsymbol{x}) - \boldsymbol{A}_t\boldsymbol{a} = \boldsymbol{0}.$$

联合高斯下，不相关推出独立，所以 $\mathcal{D}_t$ 不改变 $R(\boldsymbol{x})$ 的分布，它的均值仍是 0。把读数的实际值代入 $F(\boldsymbol{x})$ 的分解式，条件均值就是式 (16.5)。

设 R' 是 $\boldsymbol{x}'$ 处对应的剩余量，$\boldsymbol{a}' = \boldsymbol{A}_t^{-1}\boldsymbol{k}_t(\boldsymbol{x}')$。给定读数后 $F(\boldsymbol{x})$ 与 $F(\boldsymbol{x}')$ 的随机部分只有 R 与 R'，因此

$$\begin{aligned}\operatorname{Cov}(R, R') &= k(\boldsymbol{x},\boldsymbol{x}') - \boldsymbol{a}^{\top}\boldsymbol{k}_t(\boldsymbol{x}') - \boldsymbol{a}'^{\top}\boldsymbol{k}_t(\boldsymbol{x}) + \boldsymbol{a}^{\top}\boldsymbol{A}_t\boldsymbol{a}' \\ &= k(\boldsymbol{x},\boldsymbol{x}') - \boldsymbol{k}_t(\boldsymbol{x})^{\top}\boldsymbol{A}_t^{-1}\boldsymbol{k}_t(\boldsymbol{x}').\end{aligned}$$

这就是式 (16.6)。任意有限组点上同样成立，所以后验仍是高斯过程。 ■

这个证明用到联合高斯下不相关推出独立，条件高斯的一般公式及其矩阵推导可参考卷七第 2 章“随机向量与联合分布”；把核视为函数上的先验来做回归的一般理论，可参考卷八第 2 章“非参数分布与函数推断”。

读这两个公式时，注意三件事。第一，后验方差 (16.6)不含读数 $\boldsymbol{y}_t$，只取决于评价放在哪里，好读数和坏读数减少的不确定性相同。第二，无噪声时 $m_t(\boldsymbol{x}_i) = y_i$，$s_t(\boldsymbol{x}_i) = 0$，模型穿过读数。第三，$c_t(\boldsymbol{x},\boldsymbol{x}')$ 要保留，不能只留方差，后面联合抽样和批量选点都要用到不同候选点之间的后验协方差。

定理假设评价点固定，而实际的 $\boldsymbol{x}_{t+1}$ 依赖之前的读数。公式仍然成立，原因是选点规则只看 $\mathcal{D}_t$：写出整条数据的似然时，选点这一步给出的因

子不依赖 F，它在归一化时被消去，后验仍只由读数的高斯因子决定。条件分布的一般含义可参考卷七第 4 章“条件期望与条件分布”。

贯穿例：三个读数后的后验　评价 $x=1,4,7$，读数 $\boldsymbol{y}_3=(0.2,0.7,-0.3)^{\mathsf{T}}$。核矩阵是

$$\boldsymbol{K}_3=\begin{bmatrix}1 & 2^{-9} & 2^{-36}\\ 2^{-9} & 1 & 2^{-9}\\ 2^{-36} & 2^{-9} & 1\end{bmatrix},$$

其中 $2^{-9}\approx 0.002$。解线性方程 $\boldsymbol{K}_3\boldsymbol{w}=\boldsymbol{y}_3$，得到

$$\boldsymbol{w}=\boldsymbol{K}_3^{-1}\boldsymbol{y}_3\approx(0.1986,\ 0.7002,\ -0.3014)^{\mathsf{T}}.$$

看未评价的 $x=6$。到三个评价点的距离是 $5,2,1$，所以

$$\boldsymbol{k}_3(6)=(2^{-25},\ 1/16,\ 1/2)^{\mathsf{T}}.$$

由式 (16.5)，

$$m_3(6)=\boldsymbol{k}_3(6)^{\mathsf{T}}\boldsymbol{w}\approx 0.0625\times 0.7002-0.5\times 0.3014\approx -0.107.$$

由式 (16.6)，

$$s_3^2(6)=1-\boldsymbol{k}_3(6)^{\mathsf{T}}\boldsymbol{K}_3^{-1}\boldsymbol{k}_3(6)\approx 0.746,$$

即 $s_3(6)\approx 0.864$。把 2^{-9} 按 0 手算，会得到 -0.106 和 0.746，差别只在第三位小数。

图 16.6是读数逐个加入时的后验。第一个读数只影响 $x=1$ 附近，其他地方后验几乎还是先验。后面的读数逐段收紧不确定带。深色的后验均值并没有“找到” $x=6$ 的谷，这很自然：三个点都不在谷里，模型没有理由想象到它。正是这种“均值还不低、但不确定带向下伸得很远”的区域，需要由下一节的规则来评估。

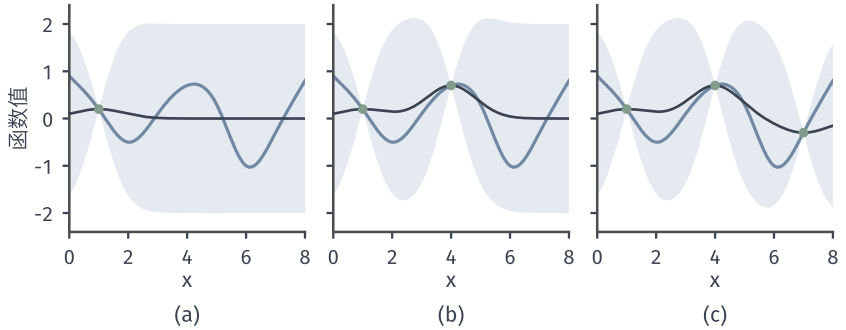


图 16.6　后验随读数更新。蓝线是目标 f，深色线是后验均值 m_t，浅蓝带是 $m_t\pm 2s_t$，绿点是读数。(a) 只有 $x=1$；(b) 加入 $x=4$；(c) 加入 $x=7$。

16.1 昂贵黑箱问题
16.2 概率代理
16.2.1 高斯过程先验
16.2.2 后验预测
16.2.3 模型设定
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

计算量也要记一笔。对 $\boldsymbol{A}_t$ 作一次 Cholesky 分解约需 $t^3/3$ 次运算，见卷二第 12 章“线性方程的直接求解”；此后每个候选点的均值需 $O(t)$ 次运算，方差需 $O(t^2)$ 次。贝叶斯优化中 t 通常只有几十到几百，这笔开销相对一次昂贵评价可以忽略，第 16.8节再核算它什么时候不能忽略。

16.2.3 模型设定

上面都假定核与噪声参数已知。实际问题中 ℓ、先验方差等**超参数**（hyperparameter）并不知道，这就有了本节的问题：模型的这些设定错了会怎样，又该如何对待它们的不确定性。

边缘似然与直接代入 常用办法是看哪组超参数最能解释已有读数。把超参数记为 θ，读数的边缘分布是 $N(\boldsymbol{m}_{0,t}, \boldsymbol{A}_t(\theta))$，其对数密度

$$\log p(\boldsymbol{y}_t \mid \theta) = -\frac{1}{2}\boldsymbol{r}^{\top}\boldsymbol{A}_t^{-1}\boldsymbol{r} - \frac{1}{2}\log\det \boldsymbol{A}_t - \frac{t}{2}\log(2\pi) \tag{16.8}$$

称为**边缘似然**（marginal likelihood）的对数，其中 $\boldsymbol{r} = \boldsymbol{y}_t - \boldsymbol{m}_{0,t}$。第一项奖励拟合读数，第二项惩罚过于灵活的模型。常见做法是取使它最大的 $\hat{\theta}$，然后把它当作真值代入定理 16.2。

直接代入回避了一个事实：超参数本身也拿不准。把不确定性计入的做法是对超参数的后验分布积分，得到混合预测。若 θ 只有有限个候选，后验概率为 w_j，候选 j 给出的均值和方差为 $m^{(j)}, v^{(j)}$，则由全方差公式，

$$\begin{aligned} \bar{m} &= \sum_j w_j m^{(j)}, \\ \bar{v} &= \sum_j w_j v^{(j)} + \sum_j w_j \big(m^{(j)} - \bar{m}\big)^2. \end{aligned} \tag{16.9}$$

第一项是平均的方差，第二项是不同超参数之间的分歧。第二项非负，所以混合预测的方差不小于各候选方差的加权平均，分歧越大增加越多。

例：两个候选长度尺度 仍用三个读数，比较 $\ell \approx 0.85$ 和 $\ell = 3$，两者的先验概率相等。由式 (16.8)算得对数边缘似然分别约为 -3.067 和 -3.106，几乎相同，按贝叶斯公式得到后验概率

$$w_1 \approx 0.51, \qquad w_2 \approx 0.49.$$

三个读数不足以区分这两种解释。

两种解释在 $x = 6$ 处的预测却差得很远：

$$\begin{aligned} \ell \approx 0.85:&\quad m = -0.107,\quad v = 0.746, \\ \ell = 3:&\quad m = 0.093,\quad v = 0.015. \end{aligned}$$

由式 (16.9)，混合预测的均值和方差为

$$\bar{m} \approx -0.009, \qquad \bar{v} \approx 0.398.$$

若只取 $\ell = 3$ 直接代入，方差 0.015 比混合预测小了约 26 倍。图 16.7(b) 显示，长度尺度大的模型在 $x = 6$ 处把标准差算得很小，而真实值 -1.0 远在它的不确定带之外。这正是直接代入的风险：边缘似然选中了一个看上去同样好的解释，却丢掉了“还有另一种解释”这条信息。

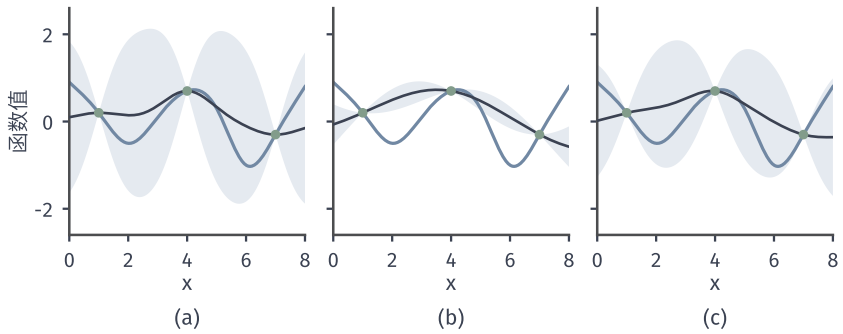


图 16.7 同样三个读数下的不同模型设定。蓝线是目标，深色线是预测均值，浅蓝带是均值上下两倍标准差。(a)$\ell \approx 0.85$；(b)$\ell = 3$，不确定带很窄，却没有盖住 $x = 6$ 附近的谷；(c) 两者按边缘似然加权的混合预测，读数之间的方差反映了两种解释的分歧。

设定要回到问题来检查 长度尺度隐含一个假设：同样的距离代表同样的变化幅度。输入的尺度是否合适直接关系这个假设。例如学习率类的参数从 10^{-4} 变到 1，在原始坐标上 10^{-4} 与 10^{-3} 几乎重合，但它们的效果可能相差很多；改用 $\log_{10}$ 坐标后，相邻量级的距离才都等于 1。多维问题中各坐标的单位不同，通常给每个坐标各设一个长度尺度。

先验的光滑程度也要与问题相符。平方指数核的样本无穷次可微，目标若有折点或跳跃，模型会用过短的长度尺度去迁就，导致全局方差偏大。可微性有限的核，如 Matérn 族，常用来表达较弱的光滑假设。

读数本身可以检验模型。依次去掉第 i 个读数，用其余读数预测它，得到留一标准化残差

$$e_i = \frac{y_i - m_{-i}(\boldsymbol{x}_i)}{\sqrt{s^2_{-i}(\boldsymbol{x}_i) + \tau^2}}. \tag{16.10}$$

模型合适时这些数大致像标准正态的取值，大量绝对值超过 3 说明模型与读数不符。贯穿例的三个读数相距较远，其余读数几乎不影响被去掉的位置，e_i 约等于读数本身，$0.2, 0.7, -0.3$ 都不大。可是读数太少时这个检查的力量也很弱，通过检查不等于模型正确。

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.3.1 改进概率（PI）
16.3.2 期望改进（EI）
16.3.3 置信下界（LCB）
16.3.4 Thompson 采样
16.3.5 知识梯度（补充）
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

低方差只说明“在这个模型下”不确定性小，不能直接等同于目标已经被准确掌握。图 16.7(b) 是一个具体的反例。后面几节的后验都默认超参数固定，这是为了把选点逻辑讲清楚；实际使用时，每轮通常重新估计或积分超参数，第 16.5.1节还会看到这样做对方差的影响。

16.3 采集函数

后验告诉了我们每个候选点上函数值的分布，但它没有说下一次该评价哪里。接下来要弄清：怎样把后验转成一个可以比较大小的分数？这个分数称为**采集函数**（acquisition function），记作 $\alpha_t(\boldsymbol{x})$，下一个评价点取使它最大的位置。

好的分数要处理一对矛盾。后验均值低的地方看起来有希望，这是利用；后验方差大的地方我们知之甚少，那里可能藏着好东西，这是探索。各种采集函数的差别就在于用什么方式把两者结合起来。

本节先假定观测无噪声，当前已观测的最好值就是

$$b_t = \min_{i \le t} f(\boldsymbol{x}_i). \tag{16.11}$$

下面统一按最小化比较。例子都用 $t = 3$ 时贯穿例的后验，$b_3 = -0.3$，取整数候选点。

16.3.1 改进概率（PI）

最朴素的想法是问：在这个位置评价，有多大可能比现在最好的结果更好？再要求至少好出一个幅度 $\xi \ge 0$，得到**改进概率**（probability of improvement，PI）：

$$\mathrm{PI}_t(\boldsymbol{x}) = \mathbb{P}\big(F(\boldsymbol{x}) < b_t - \xi \mid \mathcal{D}_t\big) = \Phi\left(\frac{b_t - \xi - m_t(\boldsymbol{x})}{s_t(\boldsymbol{x})}\right), \tag{16.12}$$

其中 $s_t(\boldsymbol{x}) > 0$，Φ 是标准正态分布函数。$s_t(\boldsymbol{x}) = 0$ 时，函数值已确定，PI 依 $m_t(\boldsymbol{x}) < b_t - \xi$ 是否成立取 1 或 0。

PI 只数“是否过线”，不问过线之后好多少。比较两个候选，取 $b_t = 0$，$\xi = 0$，

$$\text{A}:\ F \sim N(-0.1,\ 0.1^2), \qquad \text{B}:\ F \sim N(0.5,\ 1).$$

代入式 (16.12)，

$$\mathrm{PI}(\text{A}) = \Phi(1) \approx 0.841, \qquad \mathrm{PI}(\text{B}) = \Phi(-0.5) \approx 0.309.$$

PI 选 A。图 16.8的绿色面积就是这两个概率。可是 A 即使成功也只改善零点几，B 虽不常成功，一旦成功可能改善很多。

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.3.1 改进概率（PI）
16.3.2 期望改进（EI）
16.3.3 置信下界（LCB）
16.3.4 Thompson 采样
16.3.5 知识梯度（补充）
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

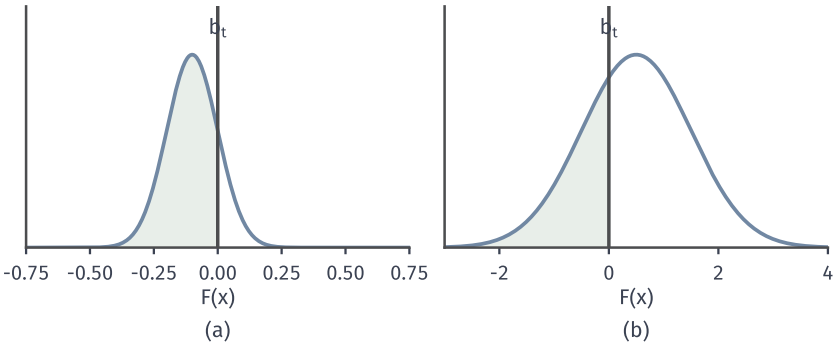


图 16.8 改进的概率与幅度。蓝线是候选点函数值的后验密度，深灰竖线是当前最好值 $b_t = 0$，浅绿面积是改进概率。(a) 候选 A：$N(-0.1, 0.1^2)$，大概率过线，但过线幅度很小。(b) 候选 B：$N(0.5, 1)$，概率较小，但左尾可以伸得很远。两图横轴比例不同。

ξ 的作用可以这样看。$\xi = 0$ 时，紧贴着当前最好点的位置，后验均值几乎等于 b_t，方差几乎为零，PI 接近 $1/2$，后面的图中可以看到，PI 的最大点恰好贴在已观测的最好点旁边，这样的评价几乎不提供新信息。取 $\xi > 0$ 把门槛压低，这种贴边的小改进就不算数了。可是 ξ 取多大没有普适答案，它取决于函数值的尺度。

16.3.2 期望改进（EI）

PI 的缺陷指明了修改方向：把幅度也算进去。若在 $\boldsymbol{x}$ 评价，新的最好值相比 b_t 的改善量是

$$\big(b_t - F(\boldsymbol{x})\big)_+ = \max\{b_t - F(\boldsymbol{x}), 0\}.$$

没有改善时计为 0，因为最好值不会变差。这个改善量的后验期望称为**期望改进**（expected improvement，EI）：

$$\mathrm{EI}_t(\boldsymbol{x}) = \mathbb{E}\big[(b_t - F(\boldsymbol{x}))_+ \mid \mathcal{D}_t\big]. \tag{16.13}$$

定理 16.3 期望改进的闭式 设 $F(\boldsymbol{x}) \mid \mathcal{D}_t \sim N(m, s^2)$。若 $s > 0$，记 $z = (b_t - m)/s$，则

$$\mathrm{EI}_t(\boldsymbol{x}) = (b_t - m)\Phi(z) + s\phi(z), \tag{16.14}$$

其中 Φ、ϕ 分别是标准正态分布函数和密度函数。若 $s = 0$，则

$$\mathrm{EI}_t(\boldsymbol{x}) = (b_t - m)_+. \tag{16.15}$$

证明 $s=0$ 时 $F(\boldsymbol{x})=m$ 是确定的数，改善量就是 $(b_t-m)_+$。

设 $s>0$，把 $F(\boldsymbol{x})$ 写成 $m+sW$，$W\sim N(0,1)$，则

$$b_t - F(\boldsymbol{x}) = s(z-W).$$

所以

$$\mathrm{EI}_t(\boldsymbol{x}) = s\int_{-\infty}^{z}(z-w)\phi(w)\,\mathrm{d}w = sz\Phi(z) - s\int_{-\infty}^{z} w\phi(w)\,\mathrm{d}w.$$

由 $\phi'(w)=-w\phi(w)$，后一个积分等于 $-\phi(z)$，于是

$$\mathrm{EI}_t(\boldsymbol{x}) = s\big(z\Phi(z)+\phi(z)\big).$$

再用 $sz=b_t-m$，即得式 (16.14)。 ■

式 (16.14)的两项正好对应利用和探索。第一项是均值带来的改进，乘上改进发生的概率；第二项随不确定性 s 增大。两者的取舍可以用导数说得更准确。把 EI 看成 (m,s) 的函数，并用 $\phi'(z)=-z\phi(z)$，得到

$$\frac{\partial \mathrm{EI}}{\partial m} = -\Phi(z) < 0, \qquad \frac{\partial \mathrm{EI}}{\partial s} = \phi(z) > 0. \tag{16.16}$$

均值越低 EI 越大，方差越大 EI 也越大，$s>0$ 时总如此。s 的增大不是白来的奖励：只有左尾越过 b_t 的部分才计入期望，右尾再长也不扣分。

回到候选 A、B，$b_t=0$。代入式 (16.14)：

$$\mathrm{EI}(\mathrm{A}) = 0.1\,\Phi(1) + 0.1\,\phi(1) \approx 0.108,$$

$$\mathrm{EI}(\mathrm{B}) = -0.5\,\Phi(-0.5) + \phi(0.5) \approx 0.198.$$

EI 选 B，把 PI 的结论翻转了。

贯穿例 看 $t=3$ 时的 $x=6$ 和 $x=8$。由第 16.2.2节的后验，

$$m_3(6) = -0.107, \quad s_3(6) = 0.864, \qquad m_3(8) = -0.151, \quad s_3(8) = 0.866.$$

对 $x=8$ 计算标准化量

$$z = \frac{-0.3 + 0.151}{0.866} \approx -0.172,$$

查表得 $\Phi(z)\approx 0.432$，$\phi(z)\approx 0.393$，于是

$$\mathrm{EI}_3(8) \approx -0.149\times 0.432 + 0.866\times 0.393 \approx 0.276.$$

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.3.1 改进概率（PI）
16.3.2 期望改进（EI）
16.3.3 置信下界（LCB）
16.3.4 Thompson 采样
16.3.5 知识梯度（补充）
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

同样算得 $\mathrm{EI}_3(6) \approx 0.257$。两者很接近，$x=8$ 略高，原因是 $x=6$ 距离高读数 0.7 的 $x=4$ 只有 2，$x=8$ 则距离更远。

16.3.3 置信下界（LCB）

第三种想法不计算期望，而是持乐观态度：把每个位置都按它“可能的好情形”来看，选最好的那个。**置信下界**（lower confidence bound，LCB）规则选择使

$$\mathrm{LCB}_t(\boldsymbol{x}) = m_t(\boldsymbol{x}) - \kappa_t s_t(\boldsymbol{x}) \tag{16.17}$$

最小的位置，其中 $\kappa_t \geq 0$ 控制探索程度。它是最大化问题中 GP-UCB 规则的最小化对应形式。$\kappa_t = 0$ 时只看均值，κ_t 越大越偏向未知区域。

规则本身很简单，容易误读的是名字。取 $\kappa = 1.96$ 时，$m_t - 1.96 s_t$ 是单个固定点的 95% 可信下限，但用它选点时，它并不自动成为有效的置信界。原因有两个。其一，选点时同时比较了所有候选，就算只有 9 个相互独立的候选，全部覆盖的概率也只有

$$0.95^9 \approx 0.63.$$

其二，$\boldsymbol{x}_{t+1}$ 是看过数据之后才选出来的，它不是一个事先固定的点。要称为有效置信界，必须说明模型、噪声以及 κ_t 随时间的取值，第 16.8.4节给出一组这样的条件。在那之前，κ_t 只应理解为一个探索权重。

三种规则的比较 表 16.3把贯穿例整数候选上的结果放在一起。三种规则在这一步都选 $x=8$，但它们在其他候选上的分数高低并不相同：LCB 在几乎未知的位置差别很小，EI 和 PI 则能根据均值差别作区分。

表 16.3 贯穿例 $t=3$ 时整数候选上的后验与采集分数，$b_3 = -0.3$，PI 取 $\xi = 0$，LCB 取 $\kappa = 2$。已观测位置 $x = 1, 4, 7$ 上标准差为 0。粗体是各列选中的候选。

x	m_3	s_3	PI	EI	LCB
0	0.099	0.866	0.322	0.182	−1.633
1	0.200	0	0	0	0.200
2	0.143	0.864	0.304	0.167	−1.585
3	0.363	0.864	0.222	0.110	−1.365
4	0.700	0	0	0	0.700
5	0.331	0.864	0.233	0.117	−1.396
6	−0.107	0.864	0.412	0.257	−1.835
7	−0.300	0	0	0	−0.300
8	−0.151	0.866	**0.432**	**0.276**	**−1.883**

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.3.1 改进概率（PI）
16.3.2 期望改进（EI）
16.3.3 置信下界（LCB）
16.3.4 Thompson 采样
16.3.5 知识梯度（补充）
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

图 16.9画出了各规则在连续的 x 上的分数。第二行的黄线中，$\xi = 0$ 的 PI 在 $x = 7$ 两侧紧贴读数处接近 $1/2$，它的连续最大点就在 $x = 7$ 旁边，这就是前面说的贴边现象；$x = 7$ 这一点本身函数值已知，不可能再改进，PI 为 0，曲线在此处断开。取 $\xi = 0.3$ 后，这个峰消失。第三行的 EI 在已观测点为 0，在两块不确定区域形成山峰，最大点在 $x = 8$。第四行的 LCB 随 κ 增大，最小点从 $x = 8$ 移向更靠中间的未知区域，$\kappa = 3$ 时连续最小点在 $x \approx 5.68$。

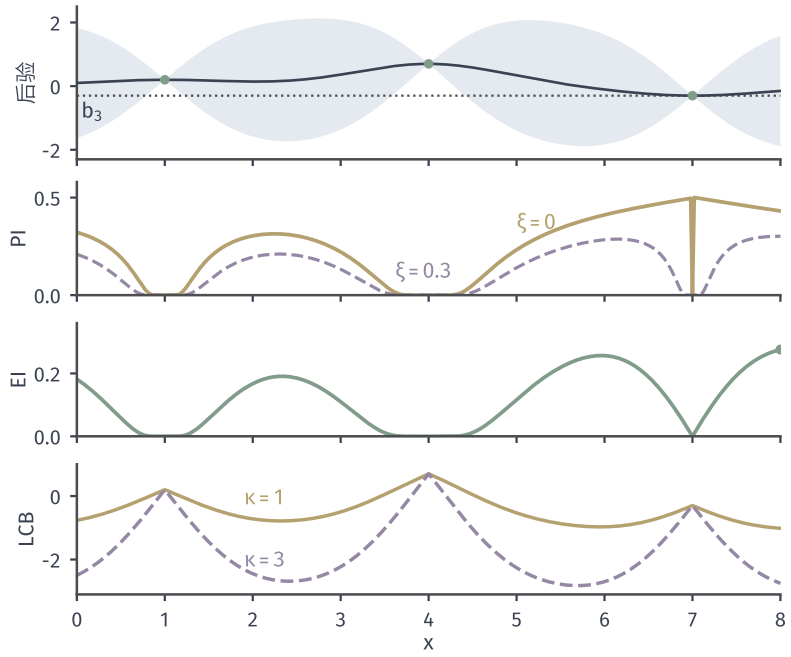


图 16.9　三种采集函数的比较，$t = 3$，读数在 $x = 1, 4, 7$。第一行：深色线是后验均值，浅蓝带是均值上下两倍标准差，点线是 b_3。第二行：改进概率，黄线 $\xi = 0$，紫虚线 $\xi = 0.3$。第三行：期望改进，绿点是最大点。第四行：置信下界，黄线 $\kappa = 1$，紫虚线 $\kappa = 3$，选点取最小点。

16.3.4 Thompson 采样

前三种规则都把后验压缩成一个分数。Thompson 采样（Thompson sampling）换了一种做法：不算分数，从当前后验抽取一整条函数 $\tilde{F}$，假装它就是真实目标，然后选它的最小点：

$$\boldsymbol{x}_{t+1} \in \arg\min_{\boldsymbol{x} \in \mathcal{C}} \tilde{F}(\boldsymbol{x}), \qquad \tilde{F} \sim F \mid \mathcal{D}_t. \tag{16.18}$$

一个位置被选中的概率，等于后验认为它是最小点的概率。乐观与谨慎不需要权重来调，而由后验分布本身决定：不确定的地方抽样起伏大，有机会被选中，但机会并不独占。

抽样要联合 在有限候选集 $\boldsymbol{x}'_1, \dots, \boldsymbol{x}'_N$ 上，抽样要从多元高斯分布 $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 抽取，$\boldsymbol{\mu}$ 和 $\boldsymbol{\Sigma}$ 分别是后验均值向量和后验协方差矩阵。常用办法是作 Cholesky 分解 $\boldsymbol{\Sigma} = \boldsymbol{L}\boldsymbol{L}^{\mathsf{T}}$，抽取标准正态向量 $\boldsymbol{z}$，令

$$\widetilde{\boldsymbol{F}} = \boldsymbol{\mu} + \boldsymbol{L}\boldsymbol{z}. \tag{16.19}$$

以 $t = 3$ 时的候选 $x = 6, 8$ 为例。后验协方差矩阵和分解为

$$\boldsymbol{\Sigma} = \begin{bmatrix} 0.746 & -0.187 \\ -0.187 & 0.750 \end{bmatrix}, \qquad \boldsymbol{L} = \begin{bmatrix} 0.864 & 0 \\ -0.217 & 0.838 \end{bmatrix}.$$

这里协方差是负的，这有一点反直觉：两点都与 $x = 7$ 相关，而 $F(7)$ 已经确定，第 16.4节会解释这个负号。

取 $\boldsymbol{z} = (1, -0.5)^{\mathsf{T}}$，代入式 (16.19)，

$$\widetilde{F}(6) = -0.107 + 0.864 = 0.757, \quad \widetilde{F}(8) = -0.151 - 0.217 - 0.419 = -0.787,$$

这条样本的最小点在 $x = 8$。取 $\boldsymbol{z} = (-1, 0.5)^{\mathsf{T}}$，则

$$\widetilde{F}(6) = -0.971, \quad \widetilde{F}(8) = 0.485,$$

这条样本选 $x = 6$。两种结果都可能发生，选点因此带有随机性。

若把各点的边际分布独立抽样，得到的就不是后验函数。图 16.10对比了在 0.1 网格上的两种抽样。(a) 联合抽样是一条光滑曲线，穿过全部读数。(b) 独立抽样忽略了相邻点的相关性，成了一串噪声，最小点总会落在方差最大的某处，这不是后验认为最可能的最小点。按 20000 条联合样本统计，最小点约四分之一的机会落在 $x = 8$ 附近，约四分之一的机会落在 $x = 6$ 附近，其余分散到 $x = 0$ 和 $x = 2$ 等位置。

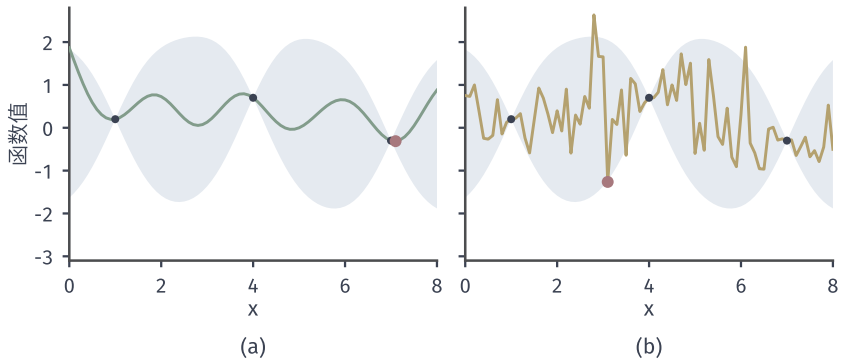


图 16.10 联合抽样与边际独立抽样。浅蓝带是 $t = 3$ 的后验均值上下两倍标准差，黑点是读数，红点是样本的最小点。(a) 联合抽样得到的绿色曲线是一条可能的函数。(b) 各网格点独立抽样得到的黄线不对应任何一条函数，把它的最小点当作选点并无依据。

计算上，N 个候选的联合抽样要作一次 $O(N^3)$ 的分解。连续搜索域上不能抽取真正的无穷维函数，通常在较大的候选集上离散化，或用有限维随机特征近似，这些都是近似的来源。

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.3.1 改进概率（PI）
16.3.2 期望改进（EI）
16.3.3 置信下界（LCB）
16.3.4 Thompson 采样
16.3.5 知识梯度（补充）
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

16.3.5 知识梯度（补充）

EI 衡量的是“这次读数本身比现在最好的值低多少”。可是我们最终要交付的是推荐解，而一次读数即使本身不好，也可能让我们更清楚哪个位置该推荐。本小节换一个问题：这次观测能让最终推荐改善多少？

定义 取一个推荐集合 $\boldsymbol{R} \subseteq \boldsymbol{C}$，当前的最优推荐价值是后验均值的最小值 $\min_{\boldsymbol{x}' \in \boldsymbol{R}} m_t(\boldsymbol{x}')$。设想在 $\boldsymbol{x}$ 再观测一次，更新后的后验均值为 m_{t+1}，它依赖尚未发生的读数，因而是随机的。**知识梯度**（knowledge gradient，KG）定义为

$$\mathrm{KG}_t(\boldsymbol{x}) = \min_{\boldsymbol{x}' \in \boldsymbol{R}} m_t(\boldsymbol{x}') - \mathbb{E}\Big[\min_{\boldsymbol{x}' \in \boldsymbol{R}} m_{t+1}(\boldsymbol{x}') \;\Big|\; \mathcal{D}_t, \boldsymbol{x}_{t+1} = \boldsymbol{x}\Big]. \tag{16.20}$$

更新后的均值以当前均值为期望，也就是

$$\mathbb{E}\big[m_{t+1}(\boldsymbol{x}') \mid \mathcal{D}_t\big] = m_t(\boldsymbol{x}').$$

min 是凹函数，凹函数的期望不超过期望处的函数值（Jensen 不等式），所以 $\mathrm{KG}_t(\boldsymbol{x}) \geq 0$。

下一次读数的预测分布是 $N(m_t(\boldsymbol{x}), s_t^2(\boldsymbol{x}) + \tau^2)$，把标准化的预测残差记作 $Z \sim N(0,1)$。把定理 16.2应用于“以当前后验为先验、只含这一个观测”的情形，可得

$$m_{t+1}(\boldsymbol{x}') = m_t(\boldsymbol{x}') + \tilde{\sigma}_t(\boldsymbol{x}', \boldsymbol{x}) Z, \quad \tilde{\sigma}_t(\boldsymbol{x}', \boldsymbol{x}) = \frac{c_t(\boldsymbol{x}', \boldsymbol{x})}{\sqrt{s_t^2(\boldsymbol{x}) + \tau^2}}. \tag{16.21}$$

每个推荐点的后验均值都随同一个 Z 线性移动，斜率取决于它与被观测位置的后验协方差。式 (16.20)中的期望因此是一维积分，有限的 $\boldsymbol{R}$ 上可以用分段线性包络精确算出，也可以用数值积分。

例：观测一个不推荐的位置 取 $\boldsymbol{R} = \{6, 7\}$，当前后验均值 $m_3(6) = -0.107$，$m_3(7) = -0.3$，当前最优推荐是 $x = 7$，价值 -0.3。考虑观测 $x = 5$，它本身不在 $\boldsymbol{R}$ 里。$x = 7$ 已观测，$c_3(7, 5) = 0$，均值不动。由 $c_3(6, 5) \approx 0.438$ 和 $s_3(5) \approx 0.864$，

$$\tilde{\sigma}_3(6, 5) \approx \frac{0.438}{0.864} \approx 0.507.$$

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.4.1 初始设计
16.4.2 采集函数求解
16.4.3 观测更新
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

新的最优推荐价值是 $\min\{-0.3,\ -0.107 + 0.507Z\}$。这个最小值可以写成 -0.3 减去 -0.3 与第二项之差的正部，代入式 (16.20)，KG 恰好是阈值为 -0.3 的 EI 公式，只是均值和标准差换成 -0.107 与 0.507：

$$\mathrm{KG}_3(5) \approx (-0.193)\Phi(-0.381) + 0.507\,\phi(-0.381) \approx 0.120.$$

这个 $x = 5$ 的读数本身比 -0.3 低的可能性不大，因而 $\mathrm{EI}_3(5) \approx 0.117$，它的价值主要来自让我们更好地判断 $x = 6$。此处的 KG 同样不要求评价点属于 $\boldsymbol{R}$，这是它与 EI 的不同，也允许最后推荐一个未曾评价的位置。

图 16.11比较了 EI 和取 $\boldsymbol{R}$ 为 0.1 网格时的 KG。两者的形状相近，但 KG 的最大点在 $x \approx 7.1$，紧靠当前最好点。在无噪声且核很光滑的模型中，贴着已知点再读一次，相当于测得该处的斜率，它能改变整段后验均值的最小位置，所以 KG 偏爱这里；而在恰好已观测的点上，读数不带来任何新信息，KG 降为 0，图中出现几个尖口。

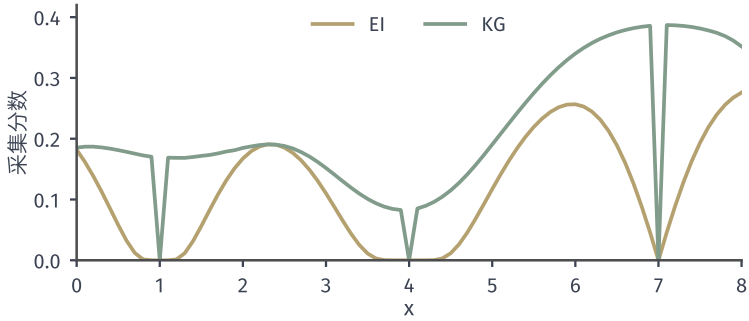


图 16.11　EI 与 KG 的对比，$t = 3$，无噪声观测。黄线是期望改进，绿线是知识梯度（推荐集合为 0.1 网格，期望由 401 个等分位点数值积分）。KG 在已观测点 $x = 1, 4, 7$ 上为 0，在紧邻这些点的位置却不为 0。

KG 的计算比 EI 贵，并且对模型更敏感。一般的实验设计问题以信息价值安排观测，可参考卷八第 9 章“观测与实验设计”；本章只把 KG 作为一种选点规则，在第 16.5节有噪声时会再次用到它。

16.4 顺序求解

有了代理和采集函数，本节把它们接成一个完整的循环，回答一个具体问题：在预算 T 内，每一轮应当按什么次序做哪些计算，新读数又怎样改变下一轮的决策。

主要思想　循环由两层组成，见图 16.12。外层是昂贵的真实评价，内层是便宜的计算：用数据建模，把模型转成分数，求分数的最大点。如果外层一次要几小时，内层花几秒钟算一个好的选点就很划算。

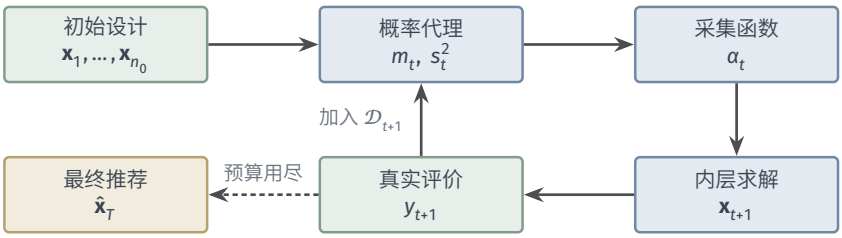


图 16.12 贝叶斯优化的循环。绿框是需要运行真实目标的步骤，蓝框是只涉及代理模型的便宜计算，黄框是最后的输出。每轮读数加入 $\mathcal{D}_{t+1}$，再回到概率代理更新。

每轮不必从头重算。第 16.2.2节的后验本身是一个高斯过程，下一个读数相对它只是一个新观测，把定理 16.2应用于“以 (m_t, c_t) 为先验、只含一个观测”的情形，就得到更新式。记 $\boldsymbol{x}^+ = \boldsymbol{x}_{t+1}$，$y^+ = y_{t+1}$，$v = s_t^2(\boldsymbol{x}^+) + \tau^2$，则

$$m_{t+1}(\boldsymbol{x}) = m_t(\boldsymbol{x}) + \frac{c_t(\boldsymbol{x}, \boldsymbol{x}^+)}{v}\big(y^+ - m_t(\boldsymbol{x}^+)\big), \tag{16.22}$$

$$c_{t+1}(\boldsymbol{x}, \boldsymbol{x}') = c_t(\boldsymbol{x}, \boldsymbol{x}') - \frac{c_t(\boldsymbol{x}, \boldsymbol{x}^+)\, c_t(\boldsymbol{x}', \boldsymbol{x}^+)}{v}. \tag{16.23}$$

式 (16.22)说的是：新读数比预期低多少，其他位置就按它们与 $\boldsymbol{x}^+$ 的后验协方差跟着调整多少，协方差为负的位置朝反方向调整。

变量 贯穿例采用整数候选集，也就是把内层问题放在九个点上求解（内层的其他做法见第 16.4.2节）。计算中用到的量如下：

- 已评价的位置与读数，长度为 t 的向量；
- 各候选点的后验均值 m_t 和后验协方差 c_t，大小为 $N \times N$，其中 $N = 9$；
- 当前最好值 b_t；
- 每个候选点的采集分数，这里用 EI。

初始化 选取分散的初始点，运行真实评价，用定理 16.2计算后验。例中初始点是 $x = 1, 4, 7$，读数 $0.2, 0.7, -0.3$，后验均值和标准差列在表 16.3中，$t = 3$，$b_3 = -0.3$。

每轮更新　当 $t < T$ 时，重复下面的步骤。

1. 计算采集分数。对每个候选点按式 (16.14)计算 EI_t。

   例中第一轮的分数见表 16.3，最大值 0.276 在 $x = 8$。

2. 选点并真实评价。取分数最大的候选 $\boldsymbol{x}^+$，运行目标，得到读数 y^+。

   例中第一轮读到 $f(8) = 0.8$，比预期的 -0.151 高出很多，预测残差为

   $$y^+ - m_3(8) \approx 0.951.$$

3. 更新后验。由式 (16.22)和式 (16.23)更新各候选点的均值和协方差，并更新 b_t。

   例中 $\upsilon = s_3^2(8) \approx 0.750$，$c_3(6,8) \approx -0.187$，于是

   $$m_4(6) \approx -0.107 + \frac{-0.187}{0.750} \times 0.951 \approx -0.345,$$

   $$s_4^2(6) \approx 0.746 - \frac{0.187^2}{0.750} \approx 0.699.$$

   $x = 6$ 的后验均值下降了，一次差的读数让另一个位置更有希望。由于 b_4 仍为 -0.3，$\mathrm{EI}_4(6)$ 由 0.257 升到 0.356，第二轮选 $x = 6$。

$c_3(6,8)$ 的负号现在可以解释了。$x = 6$ 和 $x = 8$ 都与 $x = 7$ 相关，而 $F(7)$ 已知等于 -0.3。在这个条件下，若 $F(8)$ 比预期高，函数在 $x = 7$ 附近向右上升，光滑性要求它向左下降才能经过 $F(7)$，于是 $F(6)$ 偏低。

第二轮读到 $f(6) = -1.0$，预测残差为 -0.655，$\upsilon \approx 0.699$，当前最好值变为 $b_5 = -1.0$。$x = 5$ 与 $x = 6$ 的后验协方差 $c_4(5,6) \approx 0.431$，于是

$$m_5(5) \approx 0.295 + \frac{0.431}{0.699} \times (-0.655) \approx -0.109,$$

$$s_5^2(5) \approx 0.745 - \frac{0.431^2}{0.699} \approx 0.480.$$

第三轮的分数变了样：b_5 大幅降低，所有候选的 EI 都缩小了，

$$\mathrm{EI}_5(0) \approx 0.042, \quad \mathrm{EI}_5(2) \approx 0.037, \quad \mathrm{EI}_5(3) \approx 0.020, \quad \mathrm{EI}_5(5) \approx 0.032.$$

EI 选择了 $x = 0$，读到 $f(0) = 0.9$。此时 $t = 6 = T$，预算用尽，循环结束。

最终得到的评价序列是 $x = 1, 4, 7, 8, 6, 0$，读数最小的位置是 $x = 6$，推荐 $\hat{x}_6 = 6$，目标值 -1.0。图 16.13展示了三轮的后验和 EI。第一轮两个峰高度相近；第二轮差读数把 $x = 6$ 的峰抬了起来；第三轮 b_t 下降后 EI 整体变小，算法转向还没有读数的左侧。

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.4.1 初始设计
16.4.2 采集函数求解
16.4.3 观测更新
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

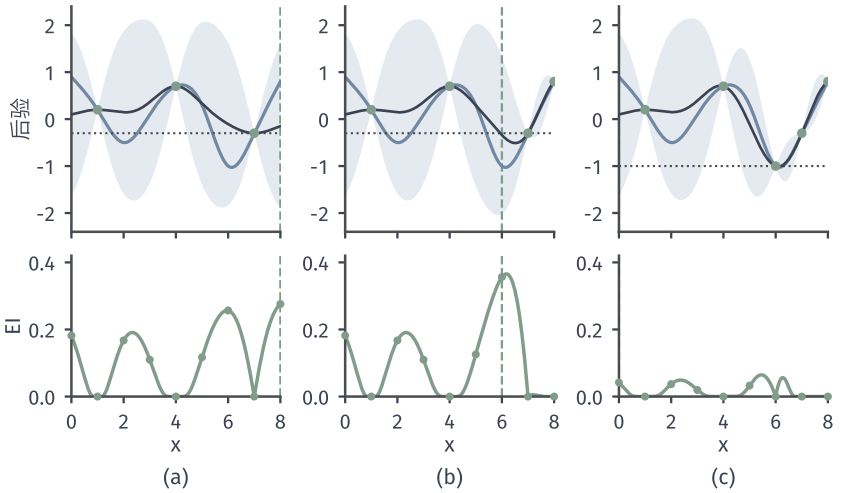


图 16.13 贯穿例的三轮选点。上行：蓝线是目标，深色线是后验均值，浅蓝带是均值上下两倍标准差，点线是当前最好值，绿点是读数。下行：绿线是 EI，小点是整数候选上的分数。竖虚线是本轮选中的位置，依次为 $x = 8$、$x = 6$、$x = 0$。

16.4.1 初始设计

循环开始之前没有任何读数，采集函数没有依据（或者取决于先验，而先验下各处相同）。第一批点因此要在没有反馈的情况下放好，这一步称为**初始设计**（initial design）。本小节的问题是：放在哪里，放多少。

先验信息较少时，初始点的任务是覆盖搜索域的不同区域，同时为估计超参数提供不同间距的点对。图 16.14比较了单位方形上放九个点的三种办法。(a) 均匀随机的点可能聚集，也可能在某些区域留白。(c) 规则网格覆盖整齐，但投影到每个坐标上只有三个不同的值。(b) 是**拉丁超立方抽样**（Latin hypercube sampling）：把每个坐标轴等分成九格，每行每列恰好放一个点，这样每个坐标轴的投影都分散。网格在高维时会失效，n 维的 3^n 个格点很快超出预算。

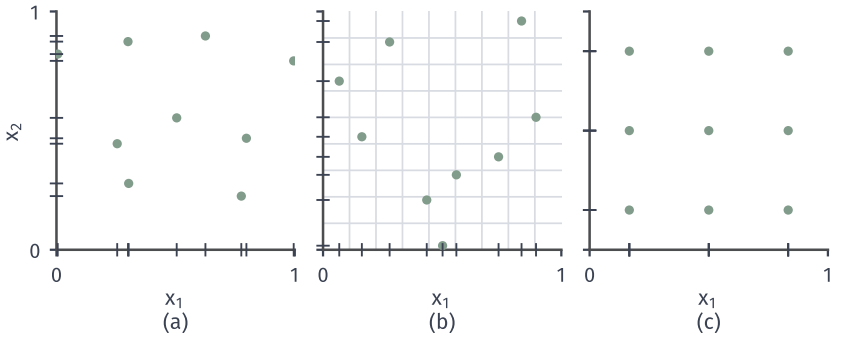


图 16.14 单位方形上九个初始点的放置（固定随机种子）。(a) 均匀随机；(b) 拉丁超立方，浅灰线是九等分的格，每行每列恰好一个点；(c) 规则网格。坐标轴上的短刻线是点在各坐标的投影，网格投影只有三个不同位置。

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.4.1 初始设计
16.4.2 采集函数求解
16.4.3 观测更新
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

初始点不是越多越好，它们挤占后面的定向搜索。图 16.15在贯穿例上固定总预算 $T = 8$，改变初始点数，其余用 EI 选点，统计 300 组随机初始点的平均终端误差。初始点不超过 4 时误差差别很小，因为这里的核是已知的，少量读数已经够用；初始点数达到 7、8 时，几乎没有定向评价的机会，平均误差升到 0.085 和 0.241。

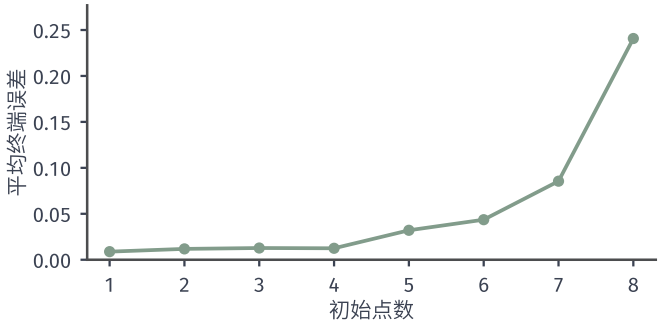


图 16.15 初始点数与最终效果。贯穿例，总预算 $T = 8$，初始点在 0.1 网格上均匀随机选取，其余用 EI 选点，纵轴是 300 组随机种子下的平均终端误差。初始点数等于 8 时全部预算都用于无反馈的覆盖。

这个例子的核已知，所以很少的初始点就够了。核的超参数需要估计时，初始点太少会使边缘似然不可靠，代理在开始几轮可能严重失真，常见的经验是取搜索维数的若干倍（如 $10n$），但这只是经验，总预算很小时要相应减少。

16.4.2 采集函数求解

每轮要解一个内层优化问题：

$$\boldsymbol{x}_{t+1} \in \arg\max_{\boldsymbol{x} \in \boldsymbol{C}} \alpha_t(\boldsymbol{x}). \tag{16.24}$$

它与外层目标的代价完全不同：α_t 是一个有解析式、可以快速求值的函数。但它一般不是凹函数，而且常有多个峰，本小节的问题就是怎样可靠地求它的最大点。

可用的导数 真实目标不提供导数，但采集函数的导数完全来自代理。由式 (16.16)和链式法则，在 $s_t(\boldsymbol{x}) > 0$ 的位置，

$$\nabla \mathrm{EI}_t(\boldsymbol{x}) = -\Phi(z)\nabla m_t(\boldsymbol{x}) + \phi(z)\nabla s_t(\boldsymbol{x}). \tag{16.25}$$

由式 (16.5)和式 (16.6)，令 $\nabla \boldsymbol{k}_t(\boldsymbol{x})$ 表示 $\boldsymbol{k}_t$ 对 $\boldsymbol{x}$ 的 Jacobi 矩阵，并设核满足 $k(\boldsymbol{x},\boldsymbol{x})$ 为常数，

$$\nabla m_t(\boldsymbol{x}) = \nabla \boldsymbol{k}_t(\boldsymbol{x})^{\top} \boldsymbol{A}_t^{-1}(\boldsymbol{y}_t - \boldsymbol{m}_{0,t}) + \nabla m_0(\boldsymbol{x}), \tag{16.26}$$

$$\nabla s_t(\boldsymbol{x}) = -\frac{\nabla \boldsymbol{k}_t(\boldsymbol{x})^{\top} \boldsymbol{A}_t^{-1} \boldsymbol{k}_t(\boldsymbol{x})}{s_t(\boldsymbol{x})}. \tag{16.27}$$

这些导数只要求核可导，不要求目标 f 可导。

用只有一个读数 $F(7) = -0.3$ 的情形验算一下。取 $x = 6$，$b = -0.3$，则

$$k(6,7) = \tfrac{1}{2}, \qquad \frac{\mathrm{d}k}{\mathrm{d}x} = -2\ln 2\,(x-7)\,k \approx 0.693.$$

后验均值与方差及其导数是

$$m = -0.15, \quad m' \approx -0.208, \quad s \approx 0.866, \quad s' \approx -0.400,$$

其中 s' 由 $(s^2)' = -2kk'$ 算得。这里 $z \approx -0.173$, $\Phi(z) \approx 0.431$, $\phi(z) \approx 0.393$，代入式 (16.25)，

$$\frac{\mathrm{dEI}}{\mathrm{d}x} \approx 0.431 \times 0.208 - 0.393 \times 0.400 \approx -0.067.$$

导数为负，说明从 $x = 6$ 向 $x = 7$ 走时，方差减小的损失超过了均值降低的收益。

多起点、候选筛选与随机搜索　一个起点的局部上升只能到达它所在的峰。常用的做法是多起点局部优化：取一批起点，通常先在大量候选上计算 α_t，挑其中分数高的作起点，再用带约束的拟牛顿法作局部上升。也可以直接在候选集上比较分数，或用第 15章的随机搜索方法。这些方法都只求一个便宜函数的最大值，不增加昂贵评价。

图 16.16是贯穿例 $t = 5$ 时的情形。八个等距起点沿 EI 爬升，到达了四个不同的局部最大点，取值约为 $0.042, 0.049, 0.065, 0.057$，全局最大点在 $x \approx 5.46$。起点 $x = 7.5$ 附近 EI 几乎为零，梯度也几乎为零，上升根本走不动，这是平坦区域的常见困难，通常的对策是对 EI 取对数后再优化。

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.4.1 初始设计
16.4.2 采集函数求解
16.4.3 观测更新
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

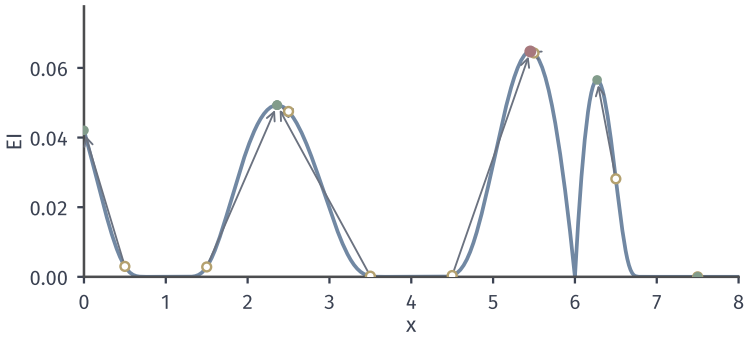


图 16.16 内层问题的多起点求解。贯穿例 $t=5$，蓝线是 EI，黄色空心点是八个起点，灰色箭头是数值上升的起止，绿点是到达的局部最大点，红点是其中最好的点 $x\approx 5.46$。

对比这一轮的正文计算，整数候选集上的最大值是 $\mathrm{EI}_5(0)\approx 0.042$，而连续域上的最大点在 $x\approx 5.46$，取值 0.065。内层问题的解法确实会改变外层的选点，这说明内层近似不是无关紧要的细节。内层近似求解也不自动得到采集函数的全局最优点；若分析某种算法的性质时假设了内层精确求解，实际运行时这个假设需要另外检查。

16.4.3 观测更新

选定位置并运行真实评价之后，要回答的问题是：新读数应当怎样进入模型。

把新读数和它的噪声信息加入 $\mathcal{D}_t$ 后，式 (16.22)、式 (16.23)更新候选点上的后验。若在搜索域的任意点上重新计算，需要更新 Cholesky 分解，也可以增量进行。设 $\boldsymbol{A}_t=\boldsymbol{L}_t\boldsymbol{L}_t^{\top}$，新矩阵的因子只在末尾加一行：

$$\boldsymbol{L}_{t+1}=\begin{bmatrix}\boldsymbol{L}_t & \boldsymbol{0}\\ \boldsymbol{\ell}^{\top} & d\end{bmatrix},\tag{16.28}$$

其中

$$\boldsymbol{\ell}=\boldsymbol{L}_t^{-1}\boldsymbol{k}_t(\boldsymbol{x}^{+}),\qquad d^2=k(\boldsymbol{x}^{+},\boldsymbol{x}^{+})+\tau^2-\boldsymbol{\ell}^{\top}\boldsymbol{\ell}.$$

求 $\boldsymbol{\ell}$ 只需一次前代，所以这一步需要 $O(t^2)$ 次运算，不必花 $O(t^3)$ 次重新分解。d^2 恰好是新读数的预测方差 v。如果这一轮重新估计了超参数，核矩阵整体改变，增量更新就不再适用，要重新分解。

这里要保留完整的历史，而不是只记住当前最好值。只记 b_t 的做法在第一轮之后只知道“最好值仍是 -0.3”，看不到 $x=8$ 的读数，也算不出 $\mathrm{EI}_4(6)$ 从 0.257 升到 0.356 这个变化。未获改进的观测也有信息，它改变相关区域的预测，进而改变后续查询的价值。第一轮的 $x=8$ 正是这种情形，图 16.13(a) 到 (b) 的变化说明了它的作用。

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.5.1 两种预测方差
16.5.2 含噪选点
16.5.3 重复评价
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

16.5 含噪观测

到目前为止，读数都是函数值本身。真实的仿真或实验常常带噪声，同一个 $\boldsymbol{x}$ 运行两次，结果不一样。设

$$y_i = f(\boldsymbol{x}_i) + \varepsilon_i, \tag{16.29}$$

其中 ε_i 相互独立，服从均值为 0、方差为 τ^2 的高斯分布。此时要分清两个对象：未知但固定的函数值 $f(\boldsymbol{x})$，和每次测量才产生的随机读数 y。这就需要回答：噪声使前面哪些做法失效，选点规则应当怎样改？

16.5.1 两种预测方差

噪声出现后，“这个位置的不确定性”有两种说法。一种是对潜在函数值 $F(\boldsymbol{x})$ 的不确定，后验方差为 $s_t^2(\boldsymbol{x})$。另一种是对下一次读数 y 的不确定，这要多加一份测量噪声。独立噪声方差为 τ^2 时，

$$\operatorname{Var}(y \mid \mathcal{D}_t, \boldsymbol{x}) = s_t^2(\boldsymbol{x}) + \tau^2. \tag{16.30}$$

这里用到 $y = F(\boldsymbol{x}) + \varepsilon$，新的 ε 与 F 及已有数据独立，方差相加。

图 16.17展示了两者的差别。浅蓝带表示潜在函数值的范围，紫色虚线表示下一次读数可能的范围。读数点不再落在后验均值上，模型会把读数“往回拉”，因为它知道读数里含有噪声；即使在读数附近，后验方差也不为零。

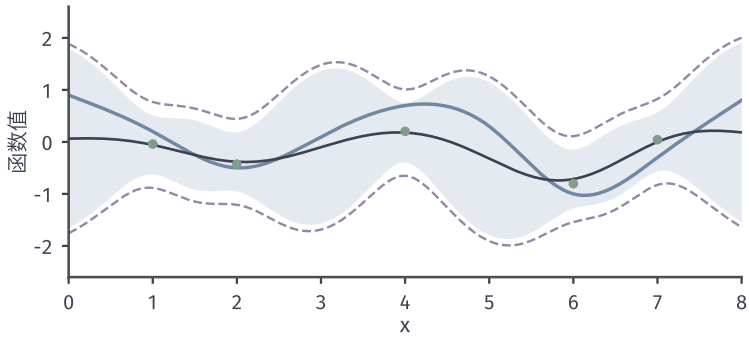


图 16.17　两种预测方差。噪声标准差 $\tau = 0.3$，绿点是五个含噪读数（固定随机种子）。蓝线是目标，深色线是后验均值，浅蓝带是 $m_t \pm 2s_t$，紫虚线是 $m_t \pm 2\sqrt{s_t^2 + \tau^2}$。

在同一位置重复读数，能减少的是第一种方差。设先验方差为 1，$\tau^2 = 0.09$，在 x 处读 n 次，由定理 16.2，

$$s^2(x) = \frac{\tau^2}{n + \tau^2}.$$

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.5.1 两种预测方差
16.5.2 含噪选点
16.5.3 重复评价
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

$n = 1, 4, 9$ 时，s^2 依次约为

$$0.083, \qquad 0.022, \qquad 0.010.$$

而下一次读数的方差始终比 s^2 多 0.09，这一份噪声不会因观测而消失。观测多了，我们越来越清楚 $f(x)$ 是多少，但下一次测量出来的数照样抖动。

方差能否只减不增 超参数固定时，由更新式 (16.23)，

$$s_{t+1}^2(\boldsymbol{x}) = s_t^2(\boldsymbol{x}) - \frac{c_t(\boldsymbol{x}, \boldsymbol{x}^+)^2}{s_t^2(\boldsymbol{x}^+) + \tau^2} \le s_t^2(\boldsymbol{x}),$$

新增观测不会使潜在值的后验方差增大。这个结论只在模型固定时成立。

重新拟合超参数就可能使方差增大。设 $k = \sigma^2 k_0$，其中 k_0 是贯穿例的核，幅度 σ^2 用边缘似然估计，无噪声。只有 $x = 1$ 的读数 1 时，估计值 $\hat{\sigma}^2 = 1$，于是

$$s^2(2) = \hat{\sigma}^2 \cdot \tfrac{3}{4} = 0.75.$$

再评价相距很远的 $x = 6$，读到 3，两点几乎不相关，幅度估计变为

$$\hat{\sigma}^2 \approx \frac{1^2 + 3^2}{2} = 5,$$

于是 $s^2(2) \approx 3.75$，反而变大了。新读数告诉模型“函数的波动比原来以为的大”，模型便下调了之前的把握。这两种情形都和“消除下一次测量的噪声”无关。

16.5.2 含噪选点

最低读数可能只是运气好 式 (16.11)的 b_t 在含噪时不能直接用读数的最小值代替。读数的最小值常常是噪声偏向负方向的那一次。图 16.18上半部分中，六个读数里最低的是 $x = 2$ 处的 -0.95（红圈），但 $f(2) = -0.5$，真实更好的 $x = 6$ 只读到 -0.55，因为那次噪声是正的。

用含噪的最低读数做阈值，会把门槛设得过低，好像已经找到一个其实并不存在的好结果。一种改法是把阈值换成已评价点上的最小后验均值，这样噪声被模型部分平滑了；这是一种具体的近似规则，并不等于对真实阈值作了正确处理。

含噪期望改进 更一致的做法是承认阈值也不确定。真实的“已评价最好值”是 $\min_i F(\boldsymbol{x}_i)$，它是随机的。把它和候选点放在同一个后验下，定义**含噪期望改进**（noisy expected improvement，NEI）：

$$\mathrm{NEI}_t(\boldsymbol{x}) = \mathbb{E}\Big[\big(\min_{i \le t} F(\boldsymbol{x}_i) - F(\boldsymbol{x})\big)_+ \;\Big|\; \mathcal{D}_t\Big]. \tag{16.31}$$

这里的期望对 $F(\boldsymbol{x}_1),\dots,F(\boldsymbol{x}_t),F(\boldsymbol{x})$ 的联合后验取，协方差不能丢：若候选点与某已评价点强相关，两者的差就不会太大。一般情形下没有闭式，常用的做法是抽取这 $t+1$ 个值的联合后验样本，取平均。

例：只有一个评价点　只有一个评价点时，NEI 可以手算。设 $\tau^2=0.09$，在 $x=2$ 读到 $y=-0.5$，候选为 $x=4$。相关系数 $\rho=1/16$，由定理 16.2，

$$F(2)\mid\mathcal{D}：\text{均值 } -0.459,\quad \text{方差 } 0.083,$$
$$F(4)\mid\mathcal{D}：\text{均值 } -0.029,\quad \text{方差 } 0.996,$$

两者的后验协方差约为 0.005。

把 $D=F(2)-F(4)$ 看成一个高斯量，其均值与方差为

$$\mathbb{E}D\approx -0.430,\qquad \operatorname{Var}D\approx 0.083+0.996-2\times 0.005\approx 1.069.$$

由于 $\mathrm{NEI}=\mathbb{E}D_+$，用式 (16.14)的同一积分，标准化后 $u\approx -0.416$，

$$\mathrm{NEI}\approx -0.430\,\Phi(u)+1.034\,\phi(u)\approx 0.233.$$

同一位置上，以读数 -0.5 为阈值的 EI 约为 0.206，以后验均值 -0.459 为阈值的 EI 约为 0.220。NEI 最大，因为它考虑了阈值 $F(2)$ 自身的不确定性：阈值可能比后验均值高，候选点就更容易改进。

图 16.18下半部分比较了三种做法。阈值用最低读数时，门槛被噪声压低，除 $x=2$ 附近外，分数都比另外两条线小（黄线）；阈值用最小后验均值时，$x=2$ 处仍有一个较高的峰，因为最小后验均值落在 $x=2$（紫虚线）；NEI 在已评价的 $x=2$ 附近凹下去，并把价值分到其他地方（绿线）。

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.5.1 两种预测方差
16.5.2 含噪选点
16.5.3 重复评价
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

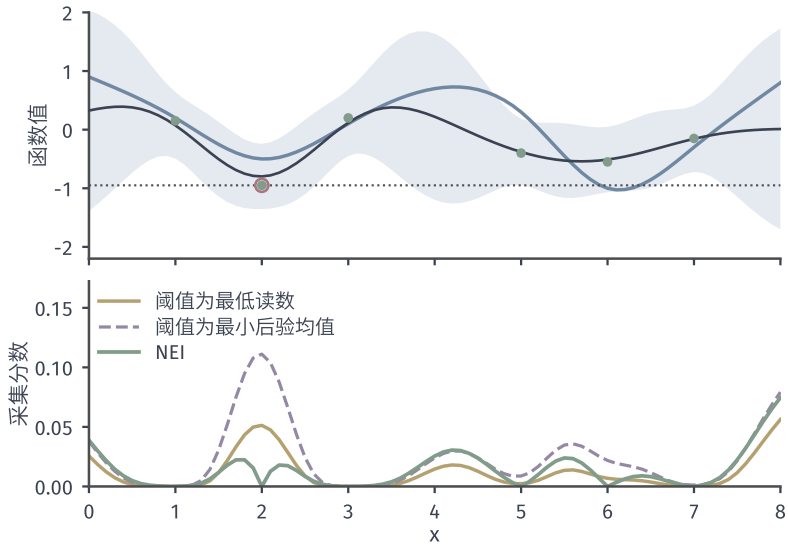


图 16.18 最低读数与含噪选点。上：$\tau = 0.3$，六个读数，噪声依次取为 $-0.05, -0.45, 0.1, -0.7, 0.45, 0.15$（手工给定，用以突出 $x = 2$ 的偶然低值），红圈是最低读数，点线是其数值；蓝线是目标，深色线是后验均值。下：三种采集分数，NEI 由 40000 个联合后验样本估计。

NEI 和知识梯度衡量的东西不同。NEI 问的是“潜在函数值能否低于已评价点”，KG 问的是“这次观测后，最终推荐的价值能改善多少”。无噪声时前者是 EI 的直接推广，后者需要再做一次前瞻。两者都在含噪时有定义，下一节就会看到它们对“重复测量”的回答相反。

16.5.3 重复评价

含噪时一个自然的动作是把同一个位置再测一次。这样做有用吗？按潜在改进的定义，答案是否定的。若 $\boldsymbol{x}$ 恰好是某个已评价点 $\boldsymbol{x}_j$，则 $\min_i F(\boldsymbol{x}_i) \le F(\boldsymbol{x}_j)$，改进量恒为 0，所以

$$\mathrm{NEI}_t(\boldsymbol{x}_j) = 0. \tag{16.32}$$

图 16.18的绿线在 $x = 2$ 处贴到零，正是这个原因。NEI 从定义上就看不到复测的价值，因为复测不产生新位置，只是更清楚地认识旧位置。

复测的价值要由信息更新的准则来衡量。式 (16.20)的 KG 没有这种限制。设两个候选 A、B，$F(\mathrm{A})$ 的后验均值 0，方差 $s^2 = 0.04$，$F(\mathrm{B})$ 的后验均值 0.1，两者后验独立，测量噪声 $\tau^2 = 0.09$。当前推荐 A。再测一次 A 后，由式 (16.21)，

$$\widetilde{\sigma} = \frac{0.04}{\sqrt{0.04 + 0.09}} \approx 0.111.$$

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.6.1 可行概率
16.6.2 评价的可行性
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

新的推荐价值是 $\min\{0.111Z,\,0.1\}$，标准化的间距 $u = 0.1/0.111 \approx 0.901$。于是

$$\begin{aligned}\mathrm{KG} &= 0 - \mathbb{E}\min\{0.111Z,\,0.1\}\\ &= 0.111\big(\phi(u) - u(1-\Phi(u))\big) \approx 0.011.\end{aligned}$$

这个值大于 0：再测一次 A 可能发现它其实比 B 差，从而改变推荐。

该重复多少次 重复次数取决于要区分的差距和噪声。设两个候选的真实差距为 Δ，噪声标准差为 τ，各读 n 次后比较平均读数，选对的概率为

$$\mathbb{P}(\text{选对}) = \Phi\left(\frac{\Delta\sqrt{n}}{\tau\sqrt{2}}\right). \tag{16.33}$$

这里用到两个平均读数之差服从 $N(\Delta, 2\tau^2/n)$。取 $\Delta = 0.2, \tau = 0.3, n = 1, 4, 9$ 时的概率依次为

$$0.681, \qquad 0.827, \qquad 0.921.$$

可见差距接近噪声水平时，一次测量基本在碰运气。代价接近的候选之间要靠复测来决定，能否负担这个复测要由预算决定。

最后要留意单次异常读数。一个比预期低 3 倍标准差的读数，可能是噪声，也可能是模型错了，比如该位置附近有一个模型没想到的窄谷。留一残差 (16.10)只能发现它异常，不能告诉我们原因。在同一位置复测可以帮助区分：回到预期附近，说明是噪声；复测仍然很低，说明应当修改模型的设定。

16.6 约束下的选点

前面的搜索域是已知的。实际问题常带约束，其中有两类要分开。已知且容易判断的约束，比如参数上下限、整数限制，在内层问题 (16.24)里直接限定搜索域即可，真实评价都发生在可行点上。另一类是未知且昂贵的约束：例如“峰值应力不超过上限”，只有仿真运行结束才知道是否满足。

设目标损失和性能上限都要运行才能测得，问题写成

$$\min_{\boldsymbol{x}\in\boldsymbol{C}} \; f(\boldsymbol{x}) \quad \text{s.t.} \quad g_j(\boldsymbol{x}) \le 0, \;\; j = 1, \dots, m. \tag{16.34}$$

一个候选点的目标值可以很好，却是不可行的。怎样让未知约束进入选点，而“最终可行”和“每次试验都可行”又有什么不同？

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.6.1 可行概率
16.6.2 评价的可行性
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

16.6.1 可行概率

对每个 g_j 也用一个代理建模，得到后验 G_j。候选点满足全部约束的后验概率称为可行概率。若当前后验下各约束相互独立，并且第 j 个约束的后验为 $N(m_j(\boldsymbol{x}), s_j^2(\boldsymbol{x}))$，$s_j(\boldsymbol{x}) > 0$，则

$$\mathrm{PF}_t(\boldsymbol{x}) = \prod_{j=1}^{m} \Phi\left(\frac{-m_j(\boldsymbol{x})}{s_j(\boldsymbol{x})}\right). \tag{16.35}$$

阈值 b_t 也要相应改变：它是已评价点中可行者的最好读数。一个不可行点读数再低，也不能作为改进的基准。可行改进的期望是

$$\mathbb{E}\Big[\big(b_t - F(\boldsymbol{x})\big)_+ \mathbf{1}\{G_j(\boldsymbol{x}) \le 0,\ \forall j\} \;\Big|\; \mathcal{D}_t\Big].$$

其中 $\mathbf{1}\{\cdot\}$ 表示事件成立时取 1、否则取 0。

当前后验下，目标改进与各约束事件相互独立时，乘积的期望等于期望的乘积，所以

$$\mathrm{cEI}_t(\boldsymbol{x}) = \mathrm{EI}_t(\boldsymbol{x}) \cdot \mathrm{PF}_t(\boldsymbol{x}). \tag{16.36}$$

独立这个条件不能省略。若目标和约束由同一个物理量驱动，相关性强，式 (16.36)就不再是可行改进的期望，需要联合积分。

贯穿例 在贯穿例上加一个约束 $g(x) = (x - 4.5)/4 \le 0$，算法只能通过评价得知它的值，用同样的核建模。三个读数为 $g(1) = -0.875$, $g(4) = -0.125$, $g(7) = 0.625$。$x = 7$ 不可行，尽管它读数最低，因此可行最好值是

$$b_3 = f(1) = 0.2.$$

计算 $x = 2$ 的 cEI。目标的后验 $m = 0.143$，$s = 0.864$，代入式 (16.14)得 $\mathrm{EI} \approx 0.374$。约束的后验 $m_g \approx -0.445$，$s_g \approx 0.864$，可行概率为

$$\Phi(0.445/0.864) = \Phi(0.515) \approx 0.697.$$

于是

$$\mathrm{cEI}(2) \approx 0.374 \times 0.697 \approx 0.261.$$

表 16.4列出几个候选的结果。不考虑约束的 EI 选择 $x = 8$，加上可行概率之后，右侧候选的分数大幅下降，最大值转到 $x = 0$。图 16.19画出了完整的曲线：$x = 7$ 的 EI 是 0.5，但 $g(7) > 0$ 已知，cEI 为 0。

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.6.1 可行概率
16.6.2 评价的可行性
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

表 16.4 贯穿例的约束选点，$t=3$，$b_3=0.2$（可行读数中最小的）。

x	EI	m_g	s_g	PF	cEI
0	0.398	−0.437	0.866	0.693	**0.276**
2	0.374	−0.445	0.864	0.697	0.261
6	0.520	0.305	0.864	0.362	0.188
8	0.549	0.313	0.866	0.359	0.197

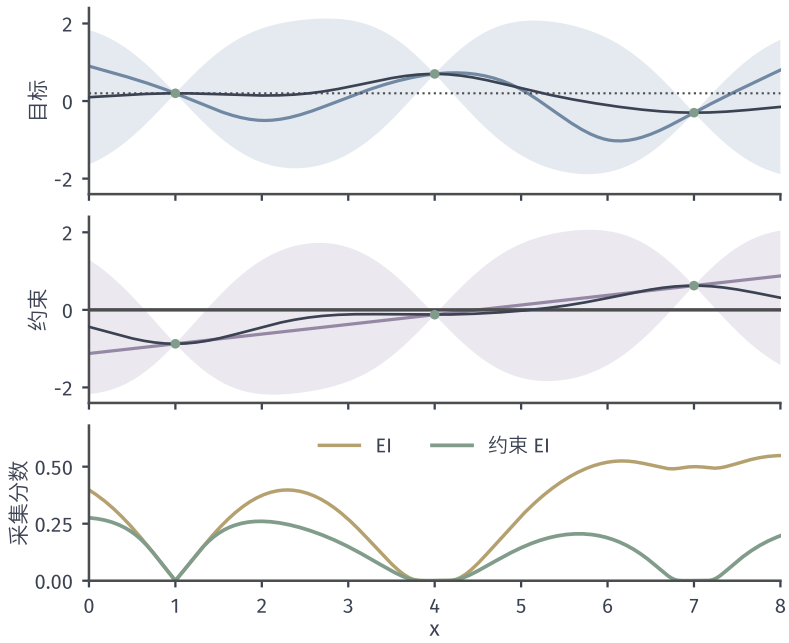


图 16.19 未知约束下的选点。上：目标的后验，蓝线是目标，点线是当前可行最好值 $b_3=0.2$。中：约束的后验，紫线是真实的 g，深灰线是边界 $g=0$。下：黄线是不考虑约束的 EI，绿线是约束 EI，$x=7$ 处 EI 较大但已知不可行，约束 EI 为 0。

还没有可行点时 读数中若没有可行点，b_t 没有定义，EI 也就无从算起。这时需要先规定一个寻找可行点的准则，最常见的是选 $\mathrm{PF}_t(\boldsymbol{x})$ 最大的位置，等找到第一个可行点后，再转入 cEI。

16.6.2 评价的可行性

约束有两种含义，到这里还没有分开：一种要求最终推荐解可行，中途的试验可以不可行；另一种要求每次试验都不能违反约束，比如试验中的设备一旦过热就会损坏。前面的 cEI 只处理第一种，它会故意到不可行区域采样，以弄清边界。

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.7.1 联合选点
16.7.2 未完成的评价
16.8 预算与结果评价
16.9 本章小结

第二种要求要严格得多。单个点的后验可行概率高并不够用。设每轮选的点可行概率都是 0.95，假设各轮近似独立，20 轮全部可行的概率只有

$$0.95^{20} \approx 0.36.$$

要保证每次试验都可行，需要三样额外的东西：能把模型与真实约束联系起来的假设（例如 g 确实来自这个高斯过程，或有已知的 Lipschitz 常数）、至少一个已知可行的初始点、以及保守的选点规则。

图 16.20展示了一种保守的做法：以 g 的后验上界 $m_g + 2s_g \le 0$ 定义安全集，每轮只在安全集内选点，示例中都取安全集的右端点。这里的约束是前面的 $g(x) = (x - 4.5)/4$，初始已知 $x = 1$ 可行。安全集三轮依次为

$$[0.66, 1.34], \qquad [0.48, 1.76], \qquad [0.32, 2.28].$$

这样的扩张靠边界附近的试验逐步推进，很慢，也可能永远到不了与初始点隔开的另一块可行区域。而且上界中的系数 2 是单点意义上的；要保证所有试验都安全，系数还须按第 16.8.4节的方式放大。

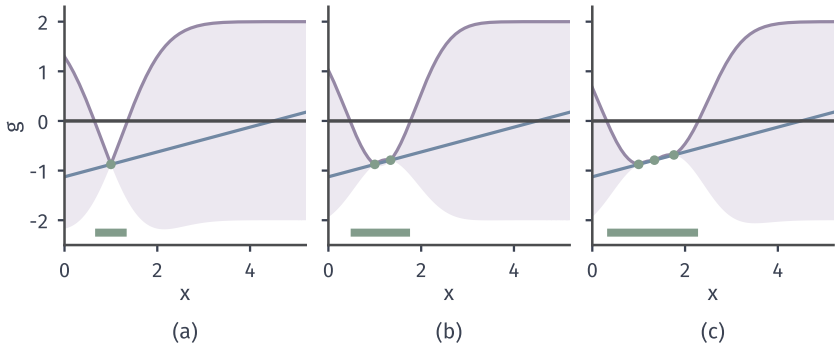


图 16.20　保守选点下安全集的扩张。蓝线是真实约束 $g(x) = (x - 4.5)/4$，深灰线是边界，浅紫带是后验 $m_g \pm 2s_g$，紫线是上界 $m_g + 2s_g$，绿点是已做的试验，底部绿色粗线是上界不超过 0 的安全集。(a)、(b)、(c) 依次是第一、二、三轮。

16.7 批量评价

到现在为止，算法一次只运行一个试验，等结果回来再决定下一个。如果手上有两台机器，就可以同时跑两个。于是要问：多个试验同时运行时，候选应当怎样选，尚未返回的试验又该如何处理？

并行带来的好处和代价都很具体。图 16.21比较了完成四次评价的三种方式。(a) 一台机器逐个运行，每次选点都能用上之前全部结果，总时长最长。(b) 两台机器同步批量运行，时长减半，但第 2 次评价没有用上第 1 次的结果。(c) 两台机器异步运行，耗时不等，一台空出来就立刻派新试验，此时另一台上的试验还没有结果。

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.7.1 联合选点
16.7.2 未完成的评价
16.8 预算与结果评价
16.9 本章小结

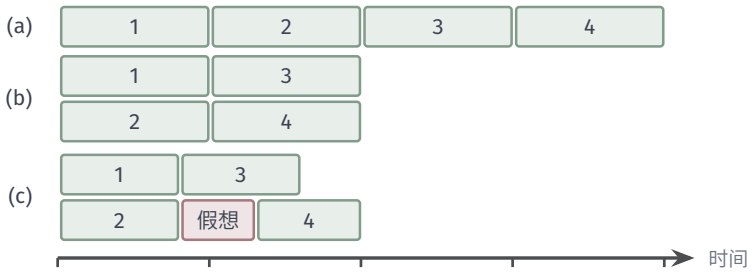


图 16.21 四次评价的三种安排，横轴是时间，每个绿框是一次评价，数字是选点顺序。(a) 串行。(b) 两台机器的同步批量。(c) 异步，两台机器上的评价耗时不等，第 3 次选点时第 2 次评价还在运行，第 2 次评价后段的红框表示这段时间里结果尚未返回，第 3 次选点的计算对它使用假想结果，它不是观测。

16.7.1 联合选点

一次选 q 个点时，最容易想到的做法是取单点采集分数最高的 q 个位置。问题在于这 q 个点常常挤在一个峰上。图 16.22是贯穿例 $t=4$ 时、在 0.25 网格上选两点的结果：单点 EI 最高的两点是 $x=6.25$ 和 $x=6$（黄方块），它们几乎重复。

应当衡量的是整批的价值。无噪声时，一批候选 $\boldsymbol{x}'_1,\dots,\boldsymbol{x}'_q$ 的批量期望改进（q-EI）是

$$\mathrm{qEI}_t(\boldsymbol{x}'_1,\dots,\boldsymbol{x}'_q)=\mathbb{E}\Big[\big(b_t-\min_{j\le q}F(\boldsymbol{x}'_j)\big)_+\;\Big|\;\mathcal{D}_t\Big]. \tag{16.37}$$

期望对这 q 个函数值的联合后验取，所以候选点之间的相关性直接影响整批的价值。

相关性怎样影响整批价值 用两个候选说清楚。设 $b_t=0$，两者的后验均为 $N(0,1)$，相关系数为 ρ。单点 EI 都是 $\phi(0)\approx 0.399$，这里记 $X=-F(\boldsymbol{x}'_1)$，$Y=-F(\boldsymbol{x}'_2)$，则

$$\mathrm{qEI}=\mathbb{E}\max\{0,X,Y\}.$$

三个数 $0,X,Y$ 从小到大排列为 $U_1\le U_2\le U_3$。对 a,b,c 两两取最大值再求和，结果等于最大数的两倍加中间数，所以

$$2U_3+U_2=\max\{0,X\}+\max\{0,Y\}+\max\{X,Y\}.$$

(X,Y) 与 $(-X,-Y)$ 同分布，取负号后最小的变成最大的，中间的仍是中间的，并且符号相反，所以 $\mathbb{E}U_2=0$。两边取期望，再用

$$\mathbb{E}\max\{0,X\}=\frac{1}{\sqrt{2\pi}},\qquad \mathbb{E}\max\{X,Y\}=\sqrt{\frac{1-\rho}{\pi}},$$

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.7.1 联合选点
16.7.2 未完成的评价
16.8 预算与结果评价
16.9 本章小结

其中第二式来自 $\max\{X,Y\} = (X+Y+|X-Y|)/2$ 和 $X-Y \sim N(0, 2(1-\rho))$，得到

$$\mathrm{qEI} = \frac{1}{\sqrt{2\pi}} + \frac{1}{2}\sqrt{\frac{1-\rho}{\pi}}. \tag{16.38}$$

取 $\rho = 1, 0.5, 0$ 时，qEI 依次约为

$$0.399, \qquad 0.598, \qquad 0.681.$$

两点完全相同时，第二个点没有价值，整批的价值就是单点 EI；越不相关，第二个点带来的额外机会越大。但即使独立，第二个点的边际价值也小于单点 EI 的 0.399，因为它和第一个点要竞争同一个“成为更好者”的位置。所以把单点分数相加不等于整批的价值。

回到贯穿例。单点 EI 最高的两点，整批 qEI ≈ 0.407，两点的单点 EI 之和却是 0.719。0.25 网格上最好的一对是 $x = 2.25$ 和 $x = 6.25$（绿点），整批 qEI ≈ 0.487，第二个点不再去挤第一个峰。

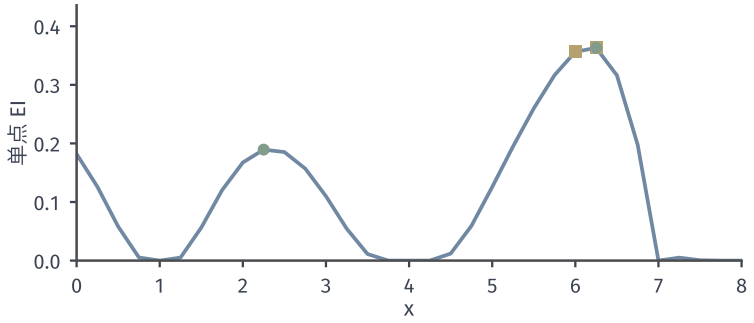


图 16.22 一次选两点。贯穿例 $t = 4$，0.25 网格，蓝线是单点 EI。黄方块是单点分数最高的两点（$x = 6$ 与 $x = 6.25$），绿点是使 qEI 最大的两点（$x = 2.25$ 与 $x = 6.25$），后者由 40000 个公共后验样本估计，$x = 6.25$ 的绿点与黄方块重合。

q 大时联合优化是 qn 维的内层问题，闭式也不再存在，通常用联合样本近似期望，再用重参数化式 (16.19)对候选位置求梯度。

16.7.2 未完成的评价

异步运行时，一台机器空出来要立刻派新试验，而另一台上的试验还没有结果。本小节的问题是：尚未返回的试验，在选点计算中该如何对待。

忽略它们不对。忽略后下一轮的选择可能恰好与运行中的位置重复。图 16.23中，若 $x = 6$ 的试验正在运行，黄线仍在 $x = 6$ 处给出高分。把运行中的位置也算作数据，就要用读数，而读数还没有。

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.8.1 评价成本
16.8.2 停止与推荐
16.8.3 推荐误差
16.8.4 保证的条件
16.9 本章小结

正确做法是对可能的结果作平均。设运行中的位置为 $\boldsymbol{x}_{\mathrm{p}}$，结果按当前预测分布取值，定义

$$\tilde{\alpha}_t(\boldsymbol{x}) = \mathbb{E}_{y_{\mathrm{p}}}\big[\alpha_t\big(\boldsymbol{x} \mid \mathcal{D}_t \cup \{(\boldsymbol{x}_{\mathrm{p}}, y_{\mathrm{p}})\}\big)\big], \tag{16.39}$$

其中期望按 $y_{\mathrm{p}} \sim N(m_t(\boldsymbol{x}_{\mathrm{p}}), s_t^2(\boldsymbol{x}_{\mathrm{p}}) + \tau^2)$ 计算，实际常用少量抽样近似。

这里用于计算的 y_{p} 称为假想结果，它不是观测，不能写进 $\mathcal{D}_t$，算完就丢弃。真实结果返回后，仍须用真实读数更新后验。

看 $\boldsymbol{x}_{\mathrm{p}} = 6$ 的情形（无噪声，$t = 3$）。对任何假想结果，$x = 6$ 处的后验方差都变为零，改善量都是 0，平均之后 $\tilde{\alpha}_3(6) = 0$。图中绿线在 $x = 6$ 降到零，附近也被压低，$x = 8$ 的分数从 0.276 降到约 0.233，因为阈值在有些假想情形下变低了。这样下一台机器不会与运行中的试验重复。

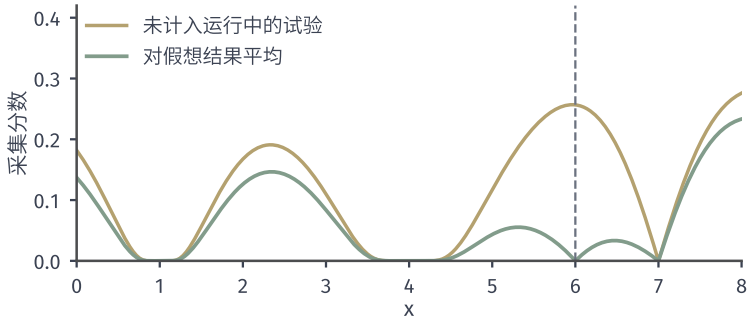


图 16.23　对运行中试验的处理。贯穿例 $t = 3$，竖虚线是运行中的位置 $x = 6$。黄线是不考虑运行中试验的 EI，绿线是对假想结果取平均之后的 EI（201 个等分位假想读数）。绿线在 $x = 6$ 处为 0。

16.8 预算与结果评价

循环总要结束。本节回答最后几个问题：预算究竟应当怎样计算，什么时候停止，交出什么，这个结果好到什么程度，以及哪些结论有理论保证。这些问题放在一起，是因为比较方法时必须固定同一套口径：搜索域、可用信息和预算。

16.8.1 评价成本

不同位置的运行代价可能差别很大，比如某个参数越大，仿真越慢。一种常见的调整是除以预测成本 $\hat{c}(\boldsymbol{x})$，选单位成本的改进最大的点：

$$\alpha_t^{\mathrm{cost}}(\boldsymbol{x}) = \frac{\mathrm{EI}_t(\boldsymbol{x})}{\hat{c}(\boldsymbol{x})}. \tag{16.40}$$

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.8.1 评价成本
16.8.2 停止与推荐
16.8.3 推荐误差
16.8.4 保证的条件
16.9 本章小结

这只是一种特定的预算策略，它不自动最优地分配剩余总预算。下面的小例子说明这一点。剩余预算是 9，候选 A 成本 1、预期收益 2，候选 B 成本 9、预期收益 16.2。单位成本的收益分别为

$$2, \qquad 1.8.$$

按单位成本选 A，用掉 1 后，剩余 8 不够运行 B，总收益只有 2；一开始就选 B，总收益为 16.2。贪心比值没有考虑“预算够不够下一个”。

时间也要分开算。评价次数少不等于总耗时短。表 16.5区分三种常被混用的时间。若一次评价只要 1 秒，贝叶斯优化的内层计算可能远超评价本身，这时随机搜索更快；若一次评价要 1 小时，每轮花 1 分钟做选点几乎没有成本。比较方法时只比较外层迭代数，等于默认了内层计算不要钱。

表 16.5　三种时间口径，c_i 是第 i 次评价的耗时，a_i 是第 i 轮算法计算的耗时，q 是并行的机器数。

口径	计算方式
串行总耗时	$\sum_i (c_i + a_i)$
并行等待时间	约 $\sum_i c_i / q$，耗时不等时更长
算法自身计算时间	$\sum_i a_i$，高斯过程每轮约 $O(t^3)$

16.8.2 停止与推荐

最直接的停止条件是预算耗尽，这不需要任何模型。也可以在采集分数很小时提前停止，例如 $\max_{\boldsymbol{x}} \mathrm{EI}_t(\boldsymbol{x})$ 低于一个阈值。这种停止依赖两件事：代理是否可信，以及内层求解是否找到了采集函数的最大点。第 16.2.3节中 $\ell = 3$ 的模型在 $x = 6$ 处方差极小，据此计算的 EI 也很小，算法就会在没有真正探索的情况下停下来。

推荐规则要在运行前说定。无噪声时可以返回已评价的最好点，贯穿例中就是 $\hat{x}_6 = 6$。含噪时，已评价的最好读数可能只是运气，通常用后验均值提出候选，例如选 $\min_{\boldsymbol{x}} m_T(\boldsymbol{x})$ 的位置，再用预留的预算在候选处复测。最后报告采用的推荐规则，以及推荐值的不确定性，不只报告一个数字。

16.8.3 推荐误差

交出 $\hat{\boldsymbol{x}}_T$ 后，自然要问它离最好的结果有多远。记 $f^\star = \inf_{\boldsymbol{x}\in\mathcal{C}} f(\boldsymbol{x})$，用**简单遗憾**（simple regret）$f(\hat{\boldsymbol{x}}_T) - f^\star$ 衡量最终结果，也就是终端的推荐误差。

另一个常见的量是**累积遗憾**（cumulative regret）：

$$R_T = \sum_{t=1}^{T} \big(f(\boldsymbol{x}_t) - f^\star\big). \tag{16.41}$$

它把每次评价相对 $f^\star$ 的损失都算进去，适用于每次试验本身就有代价的场合，这种在线损失的完整讨论可参考卷十第 3 章“部分观测、主动观测与探索”。两者回答的问题不同：贝叶斯优化的目标是最后交一个好答案，探索阶段的差读数并不算损失。

贯穿例上的简单遗憾是

$$f(6) - f^\star \approx -1.0 + 1.029 = 0.029,$$

这个差距来自算法只在整数候选上选点，而样条的最小点在 $x \approx 6.13$。

图 16.24在贯穿例上比较贝叶斯优化和均匀随机搜索，共 15 次评价，都从相同的 3 个随机点出发。(a) 是当前已评价的最好值相对 $f^\star$ 的差，贝叶斯优化第 8 次之后基本为零，15 次时平均差约 0.002，随机搜索约 0.142。(b) 的累积损失两者差别小得多，分别约为 14.2 和 16.3，因为贝叶斯优化在找到好的位置之后仍在探索其他区域。同一个方法，按不同的指标看，结论可能不同。

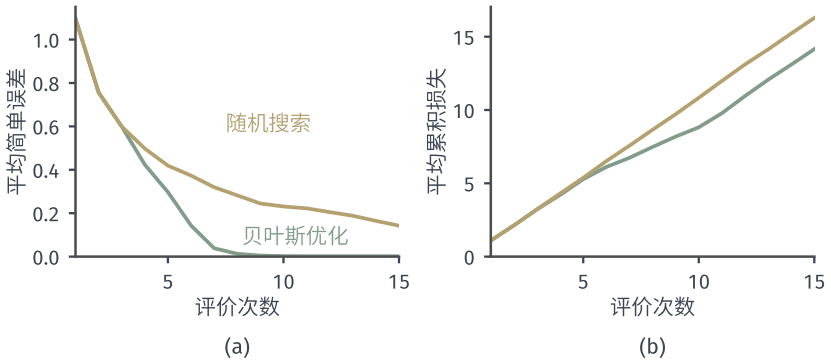


图 16.24　贯穿例上的两种误差，200 组随机初始点的平均值。绿线是贝叶斯优化（0.1 网格、EI），黄线是均匀随机搜索。(a) 当前最好值相对 $f^\star$ 的差；(b) 累积损失 (16.41)。这是单个一维目标上的教学实验，不代表一般结论。

不知道 $f^\star$ 时　贯穿例是人为构造的，$f^\star$ 可以直接算出。实际问题的最优值未知，就不能直接报告精确的推荐误差，能报告的只有依据明确的比较。可以用已知最优值的基准问题来测方法；可以用有效的下界，比如若 f 是 L-Lipschitz 的，且搜索域中每点到最近评价点的距离不超过 h，则

$$f^\star \geq \min_{i \leq T} f(\boldsymbol{x}_i) - Lh. \tag{16.42}$$

这个不等式成立，因为最小点到某个评价点的距离不超过 h，函数值的差不超过 Lh。贯穿例中六个评价点的覆盖半径 $h = 1.5$，若取 $L = 2$，下界只有 -4，松得多，可见这类下界常常只能给出保守的结论。还可以用独立的复核运行来比较候选，这能说明“比基线好多少”，不能说明“离最优多远”。

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.8.1 评价成本
16.8.2 停止与推荐
16.8.3 推荐误差
16.8.4 保证的条件
16.9 本章小结

16.8.4 保证的条件

贝叶斯优化有理论保证吗？可以说有，但条件比较具体。第 16.3.3节留下的问题是：κ_t 取多大，LCB 才是有效的置信界？下面的定理针对有限搜索域。

定理 16.4　有限搜索域上的同时置信界　设 $\boldsymbol{C}$ 是有限集，f 确实是高斯过程 F 的一个实现，读数噪声是相互独立的 $N(0,\tau^2)$，$\tau \ge 0$，且每个 $\boldsymbol{x}_t$ 只依赖 $\mathcal{D}_{t-1}$（可以再用与 F 独立的随机数）。对 $\delta \in (0,1)$，令

$$\beta_t = 2\log\frac{|\boldsymbol{C}|\pi^2 t^2}{6\delta}. \tag{16.43}$$

则以至少 $1-\delta$ 的概率，对所有 $t \ge 1$ 和所有 $\boldsymbol{x} \in \boldsymbol{C}$，都有

$$|F(\boldsymbol{x}) - m_{t-1}(\boldsymbol{x})| \le \sqrt{\beta_t}\, s_{t-1}(\boldsymbol{x}). \tag{16.44}$$

证明　先建立高斯尾的上界。设 $W \sim N(0,1)$，$c \ge 0$。把积分变量写成 $w = c + u$，有

$$\phi(c+u) = \phi(u)\, e^{-c^2/2 - cu} \le \phi(u)\, e^{-c^2/2}, \qquad u \ge 0.$$

在 $u \ge 0$ 上积分，得 $\mathbb{P}(W > c) \le \frac{1}{2} e^{-c^2/2}$，再由对称性，

$$\mathbb{P}(|W| > c) \le e^{-c^2/2}.$$

固定 t 和 $\boldsymbol{x}$。给定 $\mathcal{D}_{t-1}$ 时，$F(\boldsymbol{x})$ 服从 $N(m_{t-1}(\boldsymbol{x}), s_{t-1}^2(\boldsymbol{x}))$。若 $s_{t-1}(\boldsymbol{x}) = 0$，不等式 (16.44)必然成立；否则应用上界，

$$\mathbb{P}\big(\text{式 (16.44)对这一组}(t,\boldsymbol{x})\text{不成立} \mid \mathcal{D}_{t-1}\big) \le e^{-\beta_t/2}.$$

这个上界不依赖 $\mathcal{D}_{t-1}$，所以对 $\mathcal{D}_{t-1}$ 取期望后仍成立。

对所有 $\boldsymbol{x}$ 和所有 t 作并集界。由式 (16.43)，

$$e^{-\beta_t/2} = \frac{6\delta}{|\boldsymbol{C}|\pi^2 t^2},$$

> 于是失败概率不超过
>
> $$\sum_{t=1}^{\infty}\sum_{\boldsymbol{x}\in\boldsymbol{C}}\frac{6\delta}{|\boldsymbol{C}|\pi^2 t^2}=\sum_{t=1}^{\infty}\frac{6\delta}{\pi^2 t^2}=\delta.$$
>
> 最后一步用了 $\sum_{t\ge 1}1/t^2=\pi^2/6$。 ■

证明之所以能处理自适应选点，靠的是对每个 t 先以历史为条件，并对 $\boldsymbol{C}$ 中全部点取并集，于是不管算法选哪个点，界都成立。代价是系数比单点区间大。$|\boldsymbol{C}|=9$，$\delta=0.1$ 时，

$$\sqrt{\beta_1}\approx 3.16,\qquad \sqrt{\beta_{10}}\approx 4.38,\qquad \sqrt{\beta_{100}}\approx 5.33,$$

都比单点 95% 区间的 1.96 大得多，且随 t 缓慢增大。

有了同时置信界，LCB 的单步损失立刻受控。令 $\kappa_t=\sqrt{\beta_t}$，$\boldsymbol{x}_t$ 是 LCB_{t-1} 的最小点，$\boldsymbol{x}^\star$ 是 f 的最小点。在式 (16.44)成立的事件上，

$$f(\boldsymbol{x}_t)\le m_{t-1}(\boldsymbol{x}_t)+\kappa_t s_{t-1}(\boldsymbol{x}_t),$$

而由 $\boldsymbol{x}_t$ 的选取，

$$m_{t-1}(\boldsymbol{x}_t)-\kappa_t s_{t-1}(\boldsymbol{x}_t)\le m_{t-1}(\boldsymbol{x}^\star)-\kappa_t s_{t-1}(\boldsymbol{x}^\star)\le f^\star.$$

两式相减，得到

$$f(\boldsymbol{x}_t)-f^\star\le 2\kappa_t s_{t-1}(\boldsymbol{x}_t). \tag{16.45}$$

单步损失不超过所选位置的后验标准差的 $2\kappa_t$ 倍，评价的位置不确定性越小，损失越小。

对式 (16.45)求和，再把后验标准差之和联系到最大信息增益 γ_T，就得到累积遗憾的上界：若 $\tau>0$，$k(\boldsymbol{x},\boldsymbol{x})\le 1$，上述事件上对所有 T，

$$R_T\le\sqrt{C_1 T\beta_T\gamma_T},\qquad C_1=\frac{8}{\log(1+\tau^{-2})}, \tag{16.46}$$

其中 γ_T 是在 T 个点上观测所能获得的最大信息增益。这一步的证明需要用到高斯信息量的链式分解和方差的求和估计，篇幅较长，读者可查阅 GP-UCB 方法的原始分析。对平方指数核和紧凸搜索域，γ_T 随 T 只按 $\log T$ 的多项式增长，所以 $R_T/T\to 0$。

这个结论的适用范围要说清楚。它要求 f 确实由所用的高斯过程产生、核和噪声方差已知、内层问题精确求解、搜索域有限；连续域需要额外的光滑性条件和离散化论证。它只对这种特定的 GP 置信界方法成立，不覆盖任意代理与采集函数的组合。常用的 EI 加上每轮重新估计超参数，就不在这个定理的范围内，模型失配和内层求解误差也都要另外检查。

16.1 昂贵黑箱问题
16.2 概率代理
16.3 采集函数
16.4 顺序求解
16.5 含噪观测
16.6 约束下的选点
16.7 批量评价
16.8 预算与结果评价
16.9 本章小结

表 16.6把几种容易混淆的说法分开。

表 16.6　三种不同的主张。

主张	需要的条件
单点后验可信区间	模型正确，点在观测前固定
自适应的同时置信界	模型正确，并集界，系数随 t 增大
有限预算找到全局最优	一般不成立，需要对 f 作额外假设

最后一行值得多说一句。有限次评价只能在有限个点取值，两个点之间函数可以任意低，除非另有光滑性之类的假设，否则任何算法都不能保证找到全局最优。这也是概率模型的角色所在：它把这种假设明确写了出来，让我们知道结论依赖什么。

16.9 本章小结

本章的出发点是预算极少的黑箱问题，T 次评价要在有希望的区域和未知的区域之间分配。评价点负责收集信息，推荐解负责交付，选点规则只能使用已完成的观测。目标本身并不随机，概率描述的是我们对它的认识。

概率代理把已完成的观测变成对所有候选位置的预测。高斯过程用核表达“相近的位置函数值相近”，一个读数通过后验协方差影响相关的位置，后验方差只取决于评价放在哪里。超参数不确定时，直接代入估计值可能严重低估不确定性，低方差只说明在模型内不确定性小。

采集函数把预测变成分数：PI 只看过线的概率，EI 把幅度也计入，LCB 直接按乐观值比较，Thompson 采样按后验抽样选点，KG 衡量一次观测对最终推荐的改善。四种规则的共同之处是都在利用与探索之间折中，不同之处在于如何折中。循环的外层是昂贵评价，内层是对采集函数的优化，而内层的求解质量也影响选点。

各种推广分别改变了循环的某一环。噪声改变了阈值的含义，需要区分潜在函数值和下一次读数，复测的价值要由信息更新的准则衡量。约束在采集分数中加入可行概率，b_t 也改为可行读数中的最好值；要求每次试验都可行时，还需要额外的安全假设。并行使一批候选之间的相关性变得重要，未完成的试验要按预测分布平均，而不当作已有读数。成本则改变了预算的口径。

最后要分开三件事：模型给出的概率是否可信，优化的结果是否够好，计算的开销是否值得。特定的 GP 置信界方法有遗憾上界，但它依赖模型正确、搜索域有限和置信系数的具体取值；这些条件不满足时，算法仍可以使用，只是结论要靠实际的对照比较来支持。

第六部分

约束优化

Constrained Optimization

阅读指引

预算有上限、概率之和为一、矩阵必须正交，一旦加上这些约束，极小点可能落在边界上，梯度不再为零，前面的无约束判别和算法都要重新审视。本部分分三个层次展开。

第 17章至第 19章研究问题本身：怎样判别可行点最优，怎样用对偶问题给出可验证的下界，资源或参数变化后最优值和最优解如何改变。第 20章说明哪些问题能写成二次规划或锥规划这样结构明确的标准形式。

第 21章至第 24章研究求解。可行迭代让每一步都留在可行集内，惩罚与乘子方法允许暂时违反约束，序列二次规划用局部模型逐步逼近，内点法则沿路径从内部逼近边界。第 25章处理可行集本身是光滑流形的情形，把约束直接变成计算空间。

17.1 约束问题
17.2 可行变化
17.3 约束资格
17.4 乘子条件
17.5 二阶条件
17.6 本章小结

第 17 章

约束问题的最优性

手里有一笔钱，要分给两项开支。不受限制时，理想的分配是第一项 2、第二项 1。预算只有 2 的时候，最好的分配是 $(3/2, 1/2)$。在这一点上，目标函数的梯度不等于零：只要多花一点，目标还能更好，只是钱不够了。

第 1章的一阶条件要求梯度为零，它在这里判错了。原因是那条定理假设候选点四周都能走，而预算线上的点只能朝一部分方向移动。于是有了本章的问题：给定一个可行的候选点，怎样只用它附近的导数信息判断它是否最优？

回答分三步。第一步弄清哪些局部移动真的允许，这是集合的几何问题。第二步把“允许的移动都不能下降”翻译成目标梯度与约束梯度之间的代数关系，这一步要用到约束函数在该点足够规则的条件，结果是一组带符号限制的方程。第三步处理一阶信息分辨不了的方向，这时要看曲率，而约束的弯曲也会计入曲率。

每一步得到的结论强弱不同，有的只是最优的必要条件，有的是局部最优的充分条件，有的在凸问题中给出全局结论。全章反复区分这几种结论，也反复回到预算分配这个例子。本章的记号和条件是后面各章讨论对偶、敏感性和约束算法时的共同基础。

17.1 约束问题

把“带约束的最小化”固定成全章共用的形式，并看清边界上的最优点与无约束最优点到底差在哪里？先从预算分配的例子开始。

预算分配　设两项开支的金额为 $\boldsymbol{x} = (x_1, x_2)$，金额不能为负，总额不能超过预算 τ。理想的分配是 $\boldsymbol{c} = (2, 1)$，我们用平方距离衡量偏离理想的程度，于是要解

$$\min_{x_1, x_2} \ \frac{1}{2}\big[(x_1 - 2)^2 + (x_2 - 1)^2\big] \quad \text{s.t.} \quad x_1 + x_2 \le \tau,\ x_1 \ge 0,\ x_2 \ge 0. \tag{17.1}$$

目标的等高线是以 $\boldsymbol{c}$ 为圆心的同心圆。可行集是直角边长为 τ 的三角形。问题问的是：三角形里哪一点离 $\boldsymbol{c}$ 最近？

取 $\tau = 2$。此时 $c_1 + c_2 = 3 > 2$，$\boldsymbol{c}$ 在三角形之外。圆从 $\boldsymbol{c}$ 开始逐渐胀大，第一次碰到三角形的位置就是最优点。这一点是 $\boldsymbol{c}$ 到直线 $x_1 + x_2 = 2$ 的垂足，把 $\boldsymbol{c}$ 沿法向 $(1,1)$ 退回去就得到：

$$\boldsymbol{x}^\star = \boldsymbol{c} - \frac{3-2}{2}(1,1) = \left(\frac{3}{2}, \frac{1}{2}\right).$$

这个几何答案也可以用不等式直接验证。令 $a = 2 - x_1$，$b = 1 - x_2$，可行点满足 $a + b = 3 - x_1 - x_2 \geq 1$。由 $a^2 + b^2 \geq (a+b)^2/2$，得到

$$f(\boldsymbol{x}) = \frac{1}{2}(a^2 + b^2) \geq \frac{1}{4}(a+b)^2 \geq \frac{1}{4}.$$

等号成立当且仅当 $a = b = 1/2$，也就是 $\boldsymbol{x} = (3/2, 1/2)$，这一点可行，所以最优值是 $1/4$。这种配方只对这一个例子管用，本章要找的是能照章执行的判别方法。

现在看最优点处的梯度：

$$\nabla f(\boldsymbol{x}^\star) = \boldsymbol{x}^\star - \boldsymbol{c} = \left(-\frac{1}{2}, -\frac{1}{2}\right) \neq \boldsymbol{0}.$$

负梯度 $(1/2, 1/2)$ 指向 $\boldsymbol{c}$，沿它走目标确实下降，但它穿出了预算线。图 17.1中，蓝色箭头所指的方向就是目标“想去”却去不了的地方。这是边界最优的典型样子：梯度不为零，只是所有下降方向都被约束挡住了。

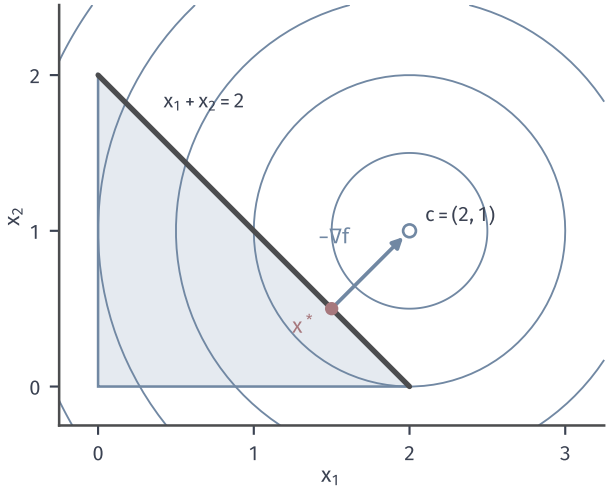


图 17.1 预算分配（$\tau = 2$）的边界最优点。浅蓝三角形是可行集，蓝色圆是目标 $\frac{1}{2}\|\boldsymbol{x} - \boldsymbol{c}\|_2^2$ 的等高线，空心点是不可行的理想分配 $\boldsymbol{c} = (2,1)$，深灰粗线是起作用的预算线。红点 $\boldsymbol{x}^\star = (3/2, 1/2)$ 处，负梯度（蓝色箭头）非零，指向可行集外。

一般形式 本章和本部分后面各章都讨论下面的问题。给定 $\boldsymbol{x} \in \mathbb{R}^n$ 的目标函数 f、不等式约束函数 $g_1, \dots, g_m$ 和等式约束函数 $h_1, \dots, h_p$，求解

$$\begin{aligned} \min_{\boldsymbol{x}\in\mathbb{R}^n} \quad & f(\boldsymbol{x}) \\ \text{s.t.} \quad & g_i(\boldsymbol{x}) \le 0, \quad i = 1, \dots, m, \\ & h_j(\boldsymbol{x}) = 0, \quad j = 1, \dots, p. \end{aligned} \tag{17.2}$$

可行集记为

$$\boldsymbol{C} = \{\boldsymbol{x} \in \mathbb{R}^n : g_i(\boldsymbol{x}) \le 0,\ i = 1, \dots, m;\ h_j(\boldsymbol{x}) = 0,\ j = 1, \dots, p\}. \tag{17.3}$$

除非另有说明，假设 f、g_i、h_j 都定义在包含 $\boldsymbol{C}$ 的开集上，并且连续可微；讨论二阶条件时再要求二阶连续可微。所有不等式都整理成“≤ 0”，这个约定决定了后面乘子的符号。预算分配写成这种形式，三个不等式约束是

$$g_1(\boldsymbol{x}) = x_1 + x_2 - \tau, \qquad g_2(\boldsymbol{x}) = -x_1, \qquad g_3(\boldsymbol{x}) = -x_2. \tag{17.4}$$

它们的梯度依次是常向量 $(1,1)$、$(-1,0)$、$(0,-1)$，都指向使约束函数增大的一侧，也就是可行集的外侧。

活动约束 站在一个可行点 $\bar{\boldsymbol{x}}$ 上，不等式约束分成两类。若 $g_i(\bar{\boldsymbol{x}}) = 0$，这条约束正好卡在边界上，稍有不慎就会违反，称它在 $\bar{\boldsymbol{x}}$ 处是**活动约束**（active constraint）。若 $g_i(\bar{\boldsymbol{x}}) < 0$，$g_i$ 是连续函数，所以在 $\bar{\boldsymbol{x}}$ 的某个邻域内仍有 $g_i < 0$，这条约束在局部不起任何限制作用。活动约束的下标集记为

$$A(\bar{\boldsymbol{x}}) = \{i \in \{1, \dots, m\} : g_i(\bar{\boldsymbol{x}}) = 0\}, \tag{17.5}$$

称为**活动集**（active set）。等式约束总在起作用，但 $A(\bar{\boldsymbol{x}})$ 只记不等式的下标。

图 17.2取 $\tau = 2$，看三个可行点。内部点 $(0.6, 0.6)$ 没有活动约束，四周都能走。预算线上的点 $(3/2, 1/2)$ 只有 g_1 活动，能走的方向少了一半。角点 $(2,0)$ 处 g_1 与 g_3 同时活动，能走的方向只剩一个楔形。虚线圆是一个小邻域，圆内真正影响移动的只有粗线。

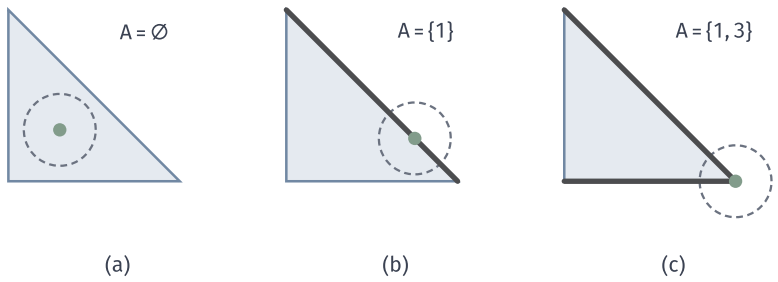


图 17.2 预算三角形（$\tau = 2$）中三个可行点的活动集。深灰粗线是该点的活动约束，虚线圆是一个小邻域。(a) 内部点 $(0.6, 0.6)$ 没有活动约束。(b) 预算线上的点 $(3/2, 1/2)$ 只有 g_1 活动。(c) 角点 $(2, 0)$ 处 g_1、g_3 同时活动。

局部与全局最小点 第 1章区分了局部与全局最优解，本章沿用这两个概念，并按习惯称最优解为最小点。称可行点 $\boldsymbol{x}^\star$ 是**局部最小点**（local minimizer），如果存在 $r > 0$，使

$$f(\boldsymbol{x}^\star) \le f(\boldsymbol{x}) \quad \text{对所有 } \boldsymbol{x} \in \boldsymbol{C},\ \|\boldsymbol{x} - \boldsymbol{x}^\star\|_2 < r. \tag{17.6}$$

若对 $\boldsymbol{x} \neq \boldsymbol{x}^\star$ 不等式都严格成立，就称为严格局部最小点。要是式 (17.6)对所有 $\boldsymbol{x} \in \boldsymbol{C}$ 成立，$\boldsymbol{x}^\star$ 就是全局最小点。

比较只在可行点之间进行，所以邻域外和可行集外的点都不参加比较。下面的例子可以看出局部和全局的差别，而这两种点都可以落在边界上。在平面上最小化 $f(\boldsymbol{x}) = x_1$，约束是

$$g(\boldsymbol{x}) = (x_2^2 - 1)^2 + 0.3\,x_2 - x_1 \le 0.$$

可行集的左边界是一条弯曲的曲线，它有两个向左伸的凸起。

图 17.3中，每个凸起的顶点都比附近的可行点更靠左，因此都是局部最小点。解一元方程求边界曲线的极小，得到上方顶点约为 $(0.294, 0.960)$，下方顶点约为 $(-0.305, -1.036)$，后者才是全局最小点。两处的梯度都等于 $(1, 0)$，并不为零。站在局部最小点上，只看附近无从知道下方还有更低的点，所以局部信息最多只能回答局部问题。

17.1 约束问题
17.2 可行变化
17.2.1 直线移动与切锥
17.2.2 一阶必要条件
17.2.3 约束的线性化
17.3 约束资格
17.4 乘子条件
17.5 二阶条件
17.6 本章小结

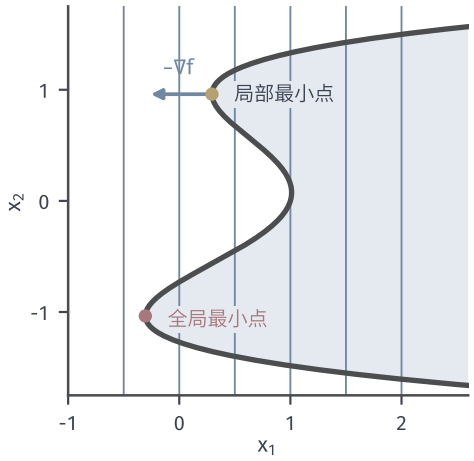


图 17.3 边界上的局部最小点与全局最小点。目标 $f(\boldsymbol{x}) = x_1$ 的等高线是竖直的蓝线，浅蓝区域是可行集 $x_1 \geq (x_2^2 - 1)^2 + 0.3x_2$，深灰粗线是边界。黄点是局部最小点，红点是全局最小点，两点的负梯度（蓝色箭头）都指向可行集外。

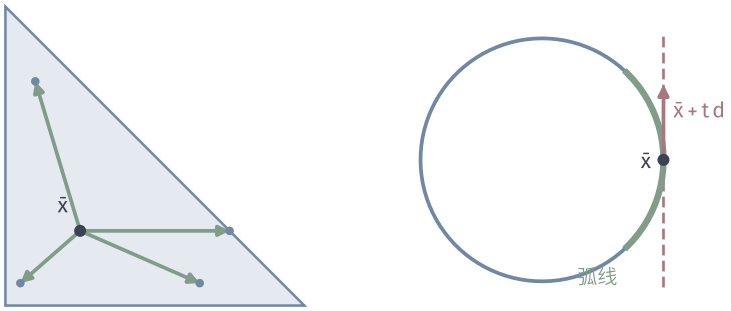
判断最优性时，本章要回答三个不同的问题：局部最小点必须满足什么（必要条件）？满足什么就一定是局部最小点（局部充分条件）？什么时候局部信息足以断定全局最优？解的存在性由第 1章的结论负责，例如预算三角形是非空紧集，目标连续，最优解一定存在。

17.2 可行变化

无约束时，最优性的论证是沿每个方向走一小步，目标都不能下降。有了约束，问题变成：站在候选点上，究竟可以朝哪些方向移动？本节先只看可行集合本身回答这个问题，再看约束函数给出的线性近似，并比较两者。这两个对象不同：前者是真实能走的方向，后者是约束函数在一阶意义下允许的方向。

17.2.1 直线移动与切锥

沿直线可行 第 1章已经定义了可行方向：若 $t > 0$ 充分小时 $\bar{\boldsymbol{x}} + t\boldsymbol{d} \in \boldsymbol{C}$，就称 $\boldsymbol{d}$ 是 $\bar{\boldsymbol{x}}$ 处的可行方向。可行集凸的时候，这个概念够用。任取 $\boldsymbol{y} \in \boldsymbol{C}$，线段 $\bar{\boldsymbol{x}} + t(\boldsymbol{y} - \bar{\boldsymbol{x}})$（$0 \leq t \leq 1$）都在 $\boldsymbol{C}$ 里，所以每个 $\boldsymbol{y} - \bar{\boldsymbol{x}}$ 都是可行方向，如图 17.4(a)。



(a) (b)

图 17.4 直线移动与弧线移动。(a) 凸集中，从 $\bar{\boldsymbol{x}}$ 到任意可行点的线段（绿色箭头）都留在集合内。(b) 可行集是单位圆周（蓝线）。从 $\bar{\boldsymbol{x}} = (1,0)$ 沿切线走的红色直线立刻离开圆周，而绿色弧线一直可行，并且在 $\bar{\boldsymbol{x}}$ 处与直线相切。

可行集弯曲时，这个定义就不够用了。设 $\boldsymbol{C}$ 是单位圆周，也就是 $h(\boldsymbol{x}) = x_1^2 + x_2^2 - 1 = 0$ 的解集，取 $\bar{\boldsymbol{x}} = (1,0)$。若 $\bar{\boldsymbol{x}} + t\boldsymbol{d}$ 对小的 $t > 0$ 都在圆周上，展开 h 并除以 t，得到

$$2d_1 + t\|\boldsymbol{d}\|_2^2 = 0 \quad \text{对所有充分小的 } t > 0.$$

令 t 取两个不同的值，两式相减得 $\|\boldsymbol{d}\|_2 = 0$。所以除零方向外没有可行方向。

可是点明明能沿圆周移动，图 17.4(b) 的绿色弧线就是这样的移动。直线走不通，弧线走得通，弧线在出发时的速度方向是 $(0,1)$。因此“能走的方向”不应理解成沿直线可行，而应理解成沿某条可行路径出发的速度。

用放大镜定义方向 为了把这个想法写成定义，可以想象拿放大镜对准 $\bar{\boldsymbol{x}}$ 看可行集。放大倍数越高，圆弧看起来越直，极限是一条直线。写成算式，就是取趋于 $\bar{\boldsymbol{x}}$ 的可行点列，把位移除以一个趋于零的正数，看它的极限。

定义 17.1 切锥 设 $\boldsymbol{C} \subseteq \mathbb{R}^n$，$\bar{\boldsymbol{x}} \in \boldsymbol{C}$。称 $\boldsymbol{d} \in \mathbb{R}^n$ 是 $\boldsymbol{C}$ 在 $\bar{\boldsymbol{x}}$ 处的切向量，如果存在可行点列 $\boldsymbol{x}^{(k)} \in \boldsymbol{C}$ 与正数列 t_k，使 $\boldsymbol{x}^{(k)} \to \bar{\boldsymbol{x}}$，$t_k \downarrow 0$，并且

$$\frac{\boldsymbol{x}^{(k)} - \bar{\boldsymbol{x}}}{t_k} \to \boldsymbol{d}. \tag{17.7}$$

全体切向量组成的集合称为**切锥**（tangent cone），记为 $\boldsymbol{T}_{\boldsymbol{C}}(\bar{\boldsymbol{x}})$。

上标 (k) 是点列编号，不表示算法迭代。这里 $1/t_k$ 就是放大倍数，点列可以是沿曲线取的点，也可以是在集合中跳跃着逼近的点。沿固定直线可

行的方向一定是切向量：取 $\boldsymbol{x}^{(k)} = \bar{\boldsymbol{x}} + t_k \boldsymbol{d}$ 即可。反过来不成立，圆周就是反例。

下面在圆周上走一遍定义。取 $t_k = 2^{-(k-1)}$，$\boldsymbol{x}^{(k)} = (\cos t_k, \sin t_k)$，放大后的位移是

$$\frac{\boldsymbol{x}^{(k)} - \bar{\boldsymbol{x}}}{t_k} = \Big(\frac{\cos t_k - 1}{t_k}, \frac{\sin t_k}{t_k}\Big).$$

前三项依次约为 $(-0.460, 0.841)$、$(-0.245, 0.959)$、$(-0.124, 0.990)$，极限是 $(0, 1)$。

图 17.5左边是原始尺度下的割线，它们越来越贴近圆弧；右边是放大后的位移，绿色箭头收拢到红色的 $(0, 1)$。换成 t_k/s（$s > 0$）作分母，极限变成 $s(0, 1)$；沿圆周的另一侧取点，得到 $-s(0, 1)$。所以切锥至少包含整条竖直直线。下一小节会用约束函数证明切锥恰好就是这条直线。

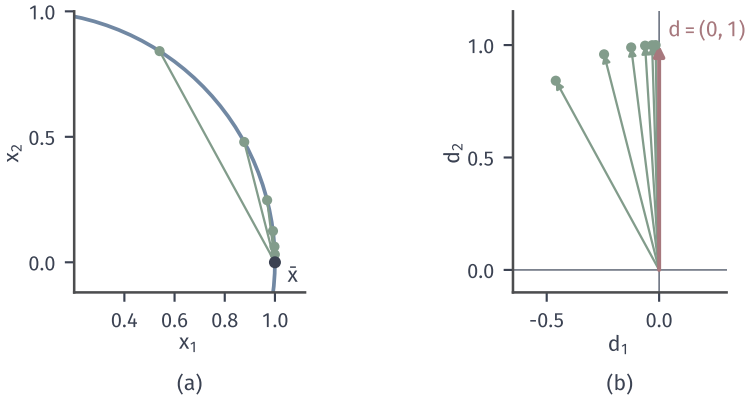


图 17.5　切向量是放大后位移的极限。可行集为单位圆周，$\bar{\boldsymbol{x}} = (1, 0)$，$t_k = 2^{-(k-1)}$（$k = 1, \ldots, 6$）。(a) 绿点是 $\boldsymbol{x}^{(k)} = (\cos t_k, \sin t_k)$，绿线是割线。(b) 绿色箭头是 $(\boldsymbol{x}^{(k)} - \bar{\boldsymbol{x}})/t_k$，它们趋于红色箭头 $\boldsymbol{d} = (0, 1)$。

切锥的基本性质　后面的证明要用到切锥的两条性质，第二条尤其重要，它允许我们用切向量的极限产生新的切向量。

> **引理 17.2　切锥是闭锥**　$T_C(\bar{\boldsymbol{x}})$ 包含零向量，对正数倍封闭，并且是闭集。

> **证明**　取 $\boldsymbol{x}^{(k)} = \bar{\boldsymbol{x}}$ 就得到零向量。若 $\boldsymbol{d}$ 对应 $(\boldsymbol{x}^{(k)}, t_k)$，$s > 0$，则同一点列配 t_k/s 给出 $s\boldsymbol{d}$。

17.1 约束问题
17.2 可行变化
17.2.1 直线移动与切锥
17.2.2 一阶必要条件
17.2.3 约束的线性化
17.3 约束资格
17.4 乘子条件
17.5 二阶条件
17.6 本章小结

再证闭性。设切向量列 $\boldsymbol{d}_l \to \boldsymbol{d}$。对每个 l，由定义可以在 $\boldsymbol{d}_l$ 对应的点列中取一项，得到可行点 $\boldsymbol{y}_l$ 和正数 $\epsilon_l < 1/l$，使

$$\|\boldsymbol{y}_l - \bar{\boldsymbol{x}}\|_2 \le \frac{1}{l}, \qquad \left\| \frac{\boldsymbol{y}_l - \bar{\boldsymbol{x}}}{\epsilon_l} - \boldsymbol{d}_l \right\|_2 \le \frac{1}{l}.$$

令 $l \to \infty$，有 $\boldsymbol{y}_l \to \bar{\boldsymbol{x}}$，$\epsilon_l \to 0$（必要时取子列使 ϵ_l 单调递减），位移比趋于 $\boldsymbol{d}$。所以 $\boldsymbol{d}$ 是切向量。 ■

图 17.6是几种常见的形状。内点处四周都能走，切锥是全空间。光滑边界上，放大后边界变成直线，切锥是半空间。角点处切锥是楔形。尖点处两条边界相切，放大后楔形被压成一条线，切锥只剩一条射线。

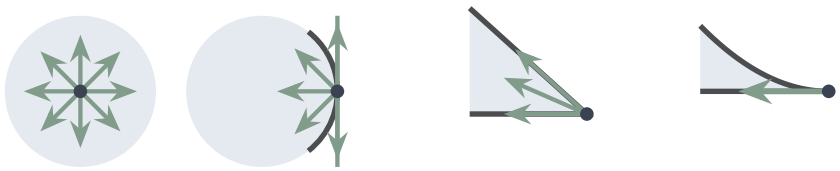


图 17.6 切锥的四种形状。浅蓝区域是可行集，黑点是基点，绿色箭头表示切向量，深灰粗线是边界。(a) 内点：全部方向。(b) 光滑边界：半空间，边界上的绿线是它的分界。(c) 角点：楔形。(d) 尖点：只有一条射线。

切锥未必是凸集。集合 $\{\boldsymbol{x} : x_1 x_2 = 0\}$ 由两条坐标轴组成，它在原点的切锥就是这两条坐标轴本身。名字里的“锥”只表示对正数倍封闭。

17.2.2 一阶必要条件

现在可以回答：局部最小点在切向量上要满足什么？直观上，沿任何可行路径出发，目标都不能以一阶速度下降。把路径换成切锥定义中的点列，证明只需要一次 Taylor 展开。

定理 17.3 切锥上的一阶必要条件 设 $\boldsymbol{x}^\star$ 是 f 在 $\boldsymbol{C}$ 上的局部最小点，f 在 $\boldsymbol{x}^\star$ 处可微。则

$$\langle \nabla f(\boldsymbol{x}^\star), \boldsymbol{d} \rangle \ge 0 \quad \text{对所有 } \boldsymbol{d} \in \boldsymbol{T}_{\boldsymbol{C}}(\boldsymbol{x}^\star). \tag{17.8}$$

证明 取切向量 $\boldsymbol{d}$ 及相应的 $\boldsymbol{x}^{(k)}$、t_k，记位移 $\boldsymbol{u}_k = \boldsymbol{x}^{(k)} - \boldsymbol{x}^\star$。$f$ 在 $\boldsymbol{x}^\star$ 处可微，所以

$$f(\boldsymbol{x}^{(k)}) - f(\boldsymbol{x}^\star) = \langle \nabla f(\boldsymbol{x}^\star), \boldsymbol{u}_k \rangle + r_k, \qquad \frac{r_k}{\|\boldsymbol{u}_k\|_2} \to 0,$$

其中 $\boldsymbol{u}_k = \boldsymbol{0}$ 时取 $r_k = 0$，比值按零理解。

k 充分大时 $\boldsymbol{x}^{(k)}$ 落在式 (17.6)的邻域内，左端非负。两边除以 t_k，得到

$$0 \le \left\langle \nabla f(\boldsymbol{x}^\star), \frac{\boldsymbol{u}_k}{t_k} \right\rangle + \frac{r_k}{t_k}.$$

由 $\boldsymbol{u}_k / t_k \to \boldsymbol{d}$ 知 $\|\boldsymbol{u}_k\|_2 / t_k$ 有界，所以 $r_k / t_k \to 0$。令 $k \to \infty$，即得式 (17.8)。 ■

在预算例上试用这个条件（$\tau = 2$）。先看不是最优的点 $\bar{\boldsymbol{x}} = (1, 1)$，它在预算线上，梯度是 $(-1, 0)$。沿预算线的切向量 $\boldsymbol{d} = (1, -1)$ 有

$$\langle \nabla f(\bar{\boldsymbol{x}}), \boldsymbol{d} \rangle = -1 < 0.$$

直接代入也一样：$f(1+s, 1-s) = \frac{1}{2}[(1-s)^2 + s^2]$ 在 $s = 0$ 处的导数是 -1。所以 $(1, 1)$ 不是局部最小点。

再看 $\boldsymbol{x}^\star = (3/2, 1/2)$。这里切锥是半平面 $\{\boldsymbol{d} : d_1 + d_2 \le 0\}$，梯度是 $(-1/2, -1/2)$，于是对切锥中每个 $\boldsymbol{d}$，

$$\langle \nabla f(\boldsymbol{x}^\star), \boldsymbol{d} \rangle = -\frac{1}{2}(d_1 + d_2) \ge 0.$$

必要条件成立。图 17.7比较了这两个点：(a) 中负梯度有沿边界的分量，绿色切向量与负梯度成锐角；(b) 中负梯度与边界垂直，沿边界两侧移动都没有一阶下降。

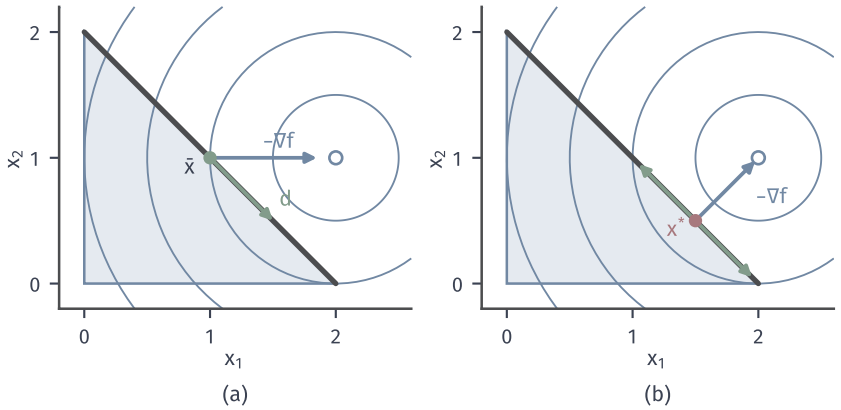


图 17.7 切向量上的一阶检验（预算例，$\tau = 2$）。空心点是理想分配 $\boldsymbol{c}$，蓝色箭头是负梯度，绿色箭头是沿预算线的切向量。(a) 在 $\bar{\boldsymbol{x}} = (1,1)$，切向量 $\boldsymbol{d} = (1,-1)$ 与负梯度成锐角，目标可以下降。(b) 在红点 $\boldsymbol{x}^\star = (3/2, 1/2)$，负梯度垂直于预算线，不存在下降的切向量。

凸可行集：法锥 可行集凸时，每个 $\boldsymbol{y} - \boldsymbol{x}^\star$ 都是切向量，所以条件可以写成对全部可行点的检验，把切向量这个中间概念拿掉。我们把这个条件从“梯度与所有可行方向的夹角”改写到集合一侧，定义所有“指向集合外”的向量。

定义 17.4 法锥 设 $\boldsymbol{C} \subseteq \mathbb{R}^n$ 是凸集，$\bar{\boldsymbol{x}} \in \boldsymbol{C}$。集合

$$\boldsymbol{N}_{\boldsymbol{C}}(\bar{\boldsymbol{x}}) = \{\boldsymbol{v} \in \mathbb{R}^n : \langle \boldsymbol{v}, \boldsymbol{y} - \bar{\boldsymbol{x}} \rangle \le 0 \text{ 对所有 } \boldsymbol{y} \in \boldsymbol{C}\} \tag{17.9}$$

称为 $\boldsymbol{C}$ 在 $\bar{\boldsymbol{x}}$ 处的**法锥**（normal cone）。

法锥里的向量与所有从 $\bar{\boldsymbol{x}}$ 出发的可行弦成钝角或直角，它们都指向集合外侧。负梯度只要落在法锥里，朝可行集内部就没有一阶下降。

定理 17.5 凸可行集上的一阶条件 设 $\boldsymbol{C}$ 是凸集，f 在包含 $\boldsymbol{C}$ 的开集上可微，$\boldsymbol{x}^\star \in \boldsymbol{C}$。若 $\boldsymbol{x}^\star$ 是 f 在 $\boldsymbol{C}$ 上的局部最小点，则

$$\langle \nabla f(\boldsymbol{x}^\star), \boldsymbol{y} - \boldsymbol{x}^\star \rangle \ge 0 \quad \text{对所有 } \boldsymbol{y} \in \boldsymbol{C}, \tag{17.10}$$

等价地，$-\nabla f(\boldsymbol{x}^\star) \in \boldsymbol{N}_{\boldsymbol{C}}(\boldsymbol{x}^\star)$。若 f 还在 $\boldsymbol{C}$ 上凸，则式 (17.10)也推出 $\boldsymbol{x}^\star$ 是全局最小点。

证明 必要性：$\boldsymbol{y}-\boldsymbol{x}^\star$ 是可行方向，也是切向量，由定理 17.3得到式 (17.10)。等价写法只是把 $\boldsymbol{v}=-\nabla f(\boldsymbol{x}^\star)$ 代入式 (17.9)。

充分性：取 $\boldsymbol{y}\in\boldsymbol{C}$，$t\in(0,1]$。由 f 的凸性，

$$f\big(\boldsymbol{x}^\star+t(\boldsymbol{y}-\boldsymbol{x}^\star)\big)\le(1-t)f(\boldsymbol{x}^\star)+tf(\boldsymbol{y}).$$

移项，除以 t，再令 $t\downarrow 0$，左端的差商趋于方向导数，于是

$$\langle\nabla f(\boldsymbol{x}^\star),\boldsymbol{y}-\boldsymbol{x}^\star\rangle\le f(\boldsymbol{y})-f(\boldsymbol{x}^\star).$$

由式 (17.10)，左端非负，所以 $f(\boldsymbol{y})\ge f(\boldsymbol{x}^\star)$。 ■

式 (17.10)称为**变分不等式**（variational inequality）。图 17.8让预算 τ 从大变小，法锥依次是三种形状。

$\tau=4$ 时最优点 $\boldsymbol{c}=(2,1)$ 在内部，法锥只有零向量，条件退化为 $\nabla f=\boldsymbol{0}$。$\tau=2$ 时最优点在预算线上，法锥是外法向 $(1,1)$ 方向的射线，$-\nabla f=(1/2,1/2)$ 落在上面。

$\tau=1/2$ 时，最优点是角点 $(1/2,0)$。法锥由两条边的外法向 $(1,1)$、$(0,-1)$ 张成。这一点可以直接核对：设 $\boldsymbol{v}\in\boldsymbol{N}_{\boldsymbol{C}}$，用沿两条边的可行弦方向 $(-1,1)$ 与 $(-1,0)$ 代入式 (17.9)，得到 $v_2\le v_1$ 与 $v_1\ge 0$，这恰好说明

$$\boldsymbol{v}=v_1(1,1)+(v_1-v_2)(0,-1),\qquad v_1\ge 0,\ v_1-v_2\ge 0.$$

角点的法锥比边上的法锥大，能接住更多方向的负梯度。

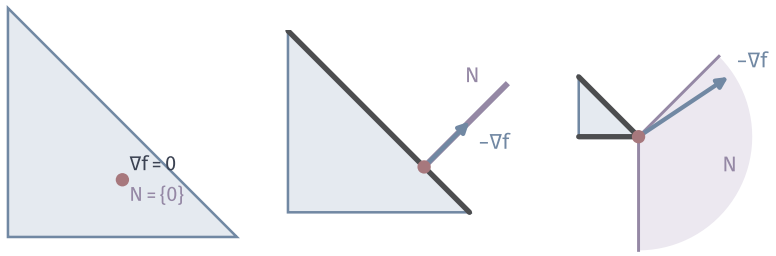


图 17.8 预算例中最优点处的法锥（紫色）。红点是最优点，蓝色箭头是负梯度（(c) 中按 0.5 倍缩短）。(a)$\tau=4$，最优点在内部，法锥为 $\{\boldsymbol{0}\}$。(b)$\tau=2$，法锥是一条射线，负梯度落在上面。(c)$\tau=1/2$，最优点是角点，法锥是两条外法向张成的楔形，负梯度落在其中。

定理的充分性同时需要可行集与目标都凸。只有目标凸是不够的：在单位圆周上最小化 $\frac{1}{2}\|\boldsymbol{x}-(2,0)\|_2^2$，点 $(-1,0)$ 的梯度是 $(-3,0)$，切向量只有

17.1 约束问题
17.2 可行变化
17.2.1 直线移动与切锥
17.2.2 一阶必要条件
17.2.3 约束的线性化
17.3 约束资格
17.4 乘子条件
17.5 二阶条件
17.6 本章小结

$(0, s)$，与梯度垂直，一阶条件成立；可它是圆周上离 $(2,0)$ 最远的点。本章后面还会回到这个例子。

17.2.3 约束的线性化

切锥描述得准，却不好算，我们无法枚举所有点列。约束以函数形式给出时，有一个自然的替代品：在基点把约束函数展开到一阶，看一阶近似允许哪些方向。

设 $\bar{\boldsymbol{x}}$ 可行，沿 $\boldsymbol{d}$ 走一小步，约束函数近似变化为

$$g_i(\bar{\boldsymbol{x}} + t\boldsymbol{d}) \approx g_i(\bar{\boldsymbol{x}}) + t\langle \nabla g_i(\bar{\boldsymbol{x}}), \boldsymbol{d}\rangle.$$

不活动的约束有余量，一阶近似不构成限制。活动约束要求这一项不为正，等式约束要求它等于零。

定义 17.6　线性化锥　设 $\bar{\boldsymbol{x}} \in \boldsymbol{C}$，约束函数在 $\bar{\boldsymbol{x}}$ 处可微。集合

$$\boldsymbol{F}(\bar{\boldsymbol{x}}) = \left\{ \boldsymbol{d} \in \mathbb{R}^n : \begin{array}{l} \langle \nabla h_j(\bar{\boldsymbol{x}}), \boldsymbol{d}\rangle = 0,\ j = 1, \dots, p, \\ \langle \nabla g_i(\bar{\boldsymbol{x}}), \boldsymbol{d}\rangle \le 0,\ i \in A(\bar{\boldsymbol{x}}) \end{array} \right\} \tag{17.11}$$

称为 $\bar{\boldsymbol{x}}$ 处的**线性化锥**（linearized cone）。

$\boldsymbol{F}(\bar{\boldsymbol{x}})$ 是有限个线性不等式的解集，一眼就能写出。例如预算例 $\tau = 1/2$ 的角点 $(1/2, 0)$ 处，g_1 和 g_3 活动，于是

$$\boldsymbol{F} = \{\boldsymbol{d} : d_1 + d_2 \le 0,\ -d_2 \le 0\}.$$

单位圆周在 $(1,0)$ 处，$\nabla h = (2,0)$，于是 $\boldsymbol{F} = \{\boldsymbol{d} : d_1 = 0\}$，正是前面算出的竖直直线。

真实能走的方向一定通过这个一阶检查，因此切锥总在线性化锥之内。

定理 17.7　切锥包含于线性化锥　设 $\bar{\boldsymbol{x}} \in \boldsymbol{C}$，$g_i$（$i \in A(\bar{\boldsymbol{x}})$）与 h_j 在 $\bar{\boldsymbol{x}}$ 处可微。则

$$\boldsymbol{T}_{\boldsymbol{C}}(\bar{\boldsymbol{x}}) \subseteq \boldsymbol{F}(\bar{\boldsymbol{x}}). \tag{17.12}$$

证明　取切向量 $\boldsymbol{d}$ 及相应的 $\boldsymbol{x}^{(k)}$、t_k，对活动的 g_i，由可微性，

$$g_i(\boldsymbol{x}^{(k)}) = g_i(\bar{\boldsymbol{x}}) + \langle \nabla g_i(\bar{\boldsymbol{x}}), \boldsymbol{x}^{(k)} - \bar{\boldsymbol{x}}\rangle + o(\|\boldsymbol{x}^{(k)} - \bar{\boldsymbol{x}}\|_2).$$

这里 $g_i(\bar{\boldsymbol{x}})=0$，$g_i(\boldsymbol{x}^{(k)})\le 0$。除以 t_k 并令 $k\to\infty$，余项如定理 17.3的证明一样趋于零，得到

$$\langle \nabla g_i(\bar{\boldsymbol{x}}),\boldsymbol{d}\rangle \le 0.$$

对 h_j 同样展开，此时左端恒为零，极限给出 $\langle \nabla h_j(\bar{\boldsymbol{x}}),\boldsymbol{d}\rangle=0$。 ■

圆周的例子到这里算完了：切锥包含竖直直线，又包含于 $\boldsymbol{F}=\{\boldsymbol{d}:d_1=0\}$，所以它就是这条直线。

式 (17.12)可以是严格包含。考虑一维约束 $g(x)=x^2\le 0$，可行集只有原点，切锥是 $\{0\}$。可是 $g'(0)=0$，线性化没有施加任何限制，$\boldsymbol{F}(0)=\mathbb{R}$。一阶近似把这条弯曲的约束看成了常值零，图 17.9(b) 的黄色线就是这个近似。

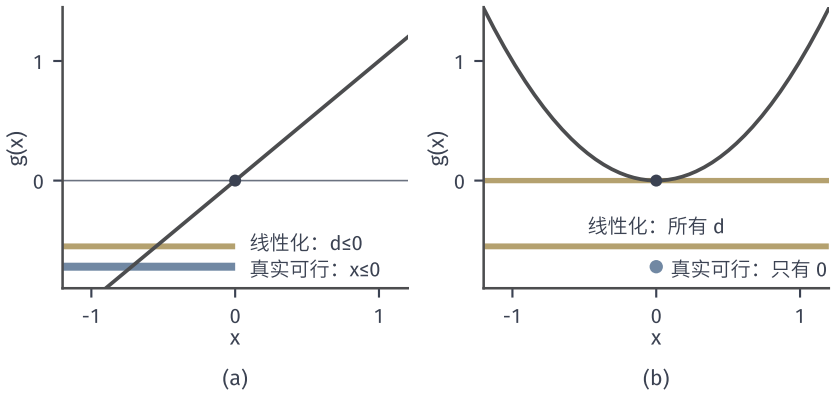


图 17.9 线性化与真实可行集的比较。深灰曲线是 g，下方黄带是线性化允许的方向，蓝带（点）是真实的可行点。(a)$g(x)=x$，线性化与真实情况一致。(b)$g(x)=x^2$，$g'(0)=0$，切线（黄色）恒为零，线性化允许所有方向，而可行集只有原点。

二维的例子能看得更清楚。取 $g_1(\boldsymbol{x})=x_2-(1-x_1)^3\le 0, g_2(\boldsymbol{x})=-x_2\le 0$，点 $\bar{\boldsymbol{x}}=(1,0)$，两条约束都活动。可行点要满足 $0\le x_2\le (1-x_1)^3$，所以 $x_1\le 1$，可行集在 $\bar{\boldsymbol{x}}$ 处形成一个向右的尖点。

梯度分别是 $(0,1)$ 和 $(0,-1)$，线性化要求 $d_2\le 0$ 且 $-d_2\le 0$，即 $d_2=0$，于是

$$\boldsymbol{F}(\bar{\boldsymbol{x}})=\{\boldsymbol{d}:d_2=0\},\qquad \boldsymbol{T}_{\boldsymbol{C}}(\bar{\boldsymbol{x}})=\{(-s,0):s\ge 0\}.$$

线性化多出了向右的半条直线。图 17.10中的红色箭头就是虚假方向：若最小化 $f(\boldsymbol{x})=-x_1$，$\bar{\boldsymbol{x}}$ 是全局最小点，而 $\boldsymbol{d}=(1,0)$ 在线性化下“可行”，并使 $\langle \nabla f,\boldsymbol{d}\rangle=-1<0$。只看线性化，就会误以为还能下降。

17.1 约束问题
17.2 可行变化
17.3 约束资格
17.3.1 线性无关约束资格
17.3.2 Mangasarian–Fromovitz 条件
17.4 乘子条件
17.5 二阶条件
17.6 本章小结

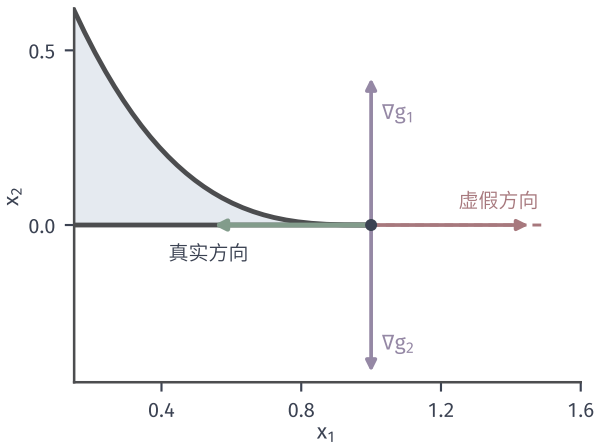


图 17.10 尖点处线性化引入虚假方向。浅蓝区域是可行集 $0 \le x_2 \le (1-x_1)^3$，紫色箭头是两条活动约束的梯度 $(0,\pm 1)$。线性化只要求 $d_2 = 0$，向左的绿色箭头是真实切向量，向右的红色箭头是虚假方向。

表 17.1对比这两个对象。下一节要回答的问题由此而来：什么时候两者相等，使我们可以用好算的线性化锥代替真实的切锥？

对比项	切锥 T_C	线性化锥 F
依赖什么	只依赖集合 C	依赖约束函数的写法
含义	真实可行变化	一阶模型允许的变化
计算	一般需要分析点列	解线性不等式
关系	总包含在 F 内	可能多出虚假方向

表 17.1 切锥与线性化锥的比较。

17.3 约束资格

定理 17.3是关于切锥的，而能算的是线性化锥。两者之间差一个包含关系。本节研究：约束函数在一点满足什么条件，线性化就没有引入虚假方向，也就是切锥等于线性化锥？这类只涉及约束函数、不涉及目标的条件称为**约束资格**（constraint qualification）。

约束资格和凸性是两回事。约束 $x^2 \le 0$ 是凸函数，问题也可以是凸的，但它的线性化在原点失效。反过来，圆周这样的非凸集合，线性化却是准确的。约束资格检查的是约束函数在这一点的一阶信息够不够用，和目标函数是否凸没有关系。

17.3.1 线性无关约束资格

先看线性化为什么可能准确。在圆周的 $(1,0)$ 处，沿切线走一步 $(1,t)$ 会离开圆周，但偏离只有 t 的二阶小量，沿圆的法向拉回去一点，就回到圆周

上。拉回动作所需的修正量比 t 小得多，放大看不出来，所以切线方向是真实可行的。

这个拉回动作要能实施，需要约束的梯度在拉回的方向上足够“有劲”，也就是各约束可以被独立地修正。这就是下面的条件。

定义 17.8　线性无关约束资格　设 $\bar{\boldsymbol{x}} \in \boldsymbol{C}$。若向量组

$$\{\nabla h_j(\bar{\boldsymbol{x}}) : j = 1, \dots, p\} \cup \{\nabla g_i(\bar{\boldsymbol{x}}) : i \in A(\bar{\boldsymbol{x}})\} \tag{17.13}$$

线性无关，就称 $\bar{\boldsymbol{x}}$ 满足**线性无关约束资格**（linear independence constraint qualification，LICQ）。

图 17.11(a) 是预算例的角点，梯度 $(1,1)$ 和 $(0,-1)$ 线性无关，LICQ 成立。图 (c) 是上一节的尖点，两个活动梯度共线，LICQ 不成立。圆周上 $\nabla h = (2x_1, 2x_2)$ 处处非零，单个非零向量线性无关，LICQ 处处成立。约束 $x^2 \le 0$ 在原点的梯度为零，LICQ 不成立。

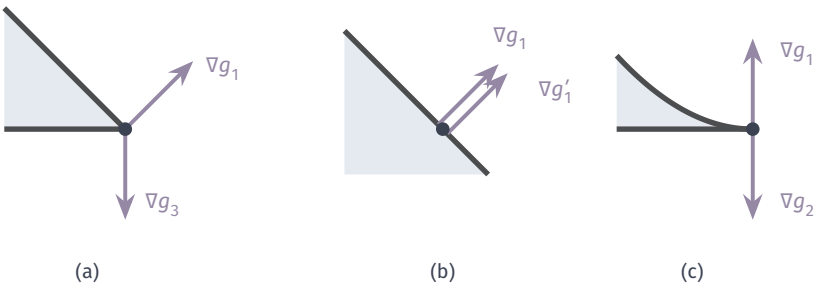


图 17.11　活动约束的梯度是否线性无关（紫色箭头）。(a) 角点处两条梯度线性无关，LICQ 成立。(b) 同一条约束写两次，可行集不变，但两个梯度相同（为看清而错开绘制），LICQ 不成立。(c) 尖点处两个梯度方向相反，LICQ 不成立。

下面的引理把“拉回”写成隐函数定理的一次应用，它产生一条真正可行的曲线。第 17.5节的二阶必要条件还要用这条曲线。隐函数定理说：方程关于待解变量的 Jacobian 可逆时，方程在局部确定唯一的连续可微解，详见卷二第 22 章“隐函数与反函数”。

引理 17.9　沿线性化方向的可行曲线　设约束函数在 $\bar{\boldsymbol{x}} \in \boldsymbol{C}$ 附近连续可微，$\boldsymbol{d} \in \boldsymbol{F}(\bar{\boldsymbol{x}})$。设 $W \subseteq A(\bar{\boldsymbol{x}})$ 满足：$i \in W$ 时 $\langle \nabla g_i(\bar{\boldsymbol{x}}), \boldsymbol{d} \rangle = 0$，$i \in A(\bar{\boldsymbol{x}}) \setminus W$ 时 $\langle \nabla g_i(\bar{\boldsymbol{x}}), \boldsymbol{d} \rangle < 0$，并且 $\nabla h_j(\bar{\boldsymbol{x}})$（全部 j）与 $\nabla g_i(\bar{\boldsymbol{x}})$（$i \in W$）线性无关。则存在 $\delta > 0$ 和连续可微曲线 $\boldsymbol{x} : (-\delta, \delta) \to \mathbb{R}^n$，满足

$$\boldsymbol{x}(0) = \bar{\boldsymbol{x}}, \qquad \boldsymbol{x}'(0) = \boldsymbol{d}, \qquad \boldsymbol{x}(t) \in \boldsymbol{C} \ \ (0 \le t < \delta), \tag{17.14}$$

并且 $h_j(\boldsymbol{x}(t))=0$，$g_i(\boldsymbol{x}(t))=0$（$i\in W$）对 $|t|<\delta$ 成立。若约束函数还二阶连续可微，则曲线也二阶连续可微。

证明　把 h_j（全部 j）和 g_i（$i\in W$）合成向量值函数 $\boldsymbol{c}$，记它在 $\bar{\boldsymbol{x}}$ 处的 Jacobian 为 $\boldsymbol{J}\in\mathbb{R}^{r\times n}$。由假设，$\boldsymbol{J}$ 行满秩，$\boldsymbol{J}\boldsymbol{d}=\boldsymbol{0}$。考虑关于 $\boldsymbol{w}\in\mathbb{R}^r$ 的方程

$$\Phi(t,\boldsymbol{w})=\boldsymbol{c}(\bar{\boldsymbol{x}}+t\boldsymbol{d}+\boldsymbol{J}^{\top}\boldsymbol{w})=\boldsymbol{0}.$$

这里 $\bar{\boldsymbol{x}}+t\boldsymbol{d}$ 是沿切线走，$\boldsymbol{J}^{\top}\boldsymbol{w}$ 是沿约束法向的修正。

$\Phi(0,\boldsymbol{0})=\boldsymbol{0}$，关于 $\boldsymbol{w}$ 的 Jacobian 在该点是 $\boldsymbol{J}\boldsymbol{J}^{\top}$，行满秩保证它可逆。由隐函数定理，存在连续可微的 $\boldsymbol{w}(t)$（$|t|<\delta$），$\boldsymbol{w}(0)=\boldsymbol{0}$，$\Phi(t,\boldsymbol{w}(t))=\boldsymbol{0}$。隐函数的导数公式给出

$$\boldsymbol{w}'(0)=-(\boldsymbol{J}\boldsymbol{J}^{\top})^{-1}\boldsymbol{J}\boldsymbol{d}=\boldsymbol{0}.$$

令

$$\boldsymbol{x}(t)=\bar{\boldsymbol{x}}+t\boldsymbol{d}+\boldsymbol{J}^{\top}\boldsymbol{w}(t),$$

于是 $\boldsymbol{x}'(0)=\boldsymbol{d}$，且 $\boldsymbol{c}(\boldsymbol{x}(t))=\boldsymbol{0}$。剩下的约束分两类检查。对 $i\in A(\bar{\boldsymbol{x}})\setminus W$，有

$$g_i(\boldsymbol{x}(t))=t\langle\nabla g_i(\bar{\boldsymbol{x}}),\boldsymbol{d}\rangle+o(t),$$

小的 $t>0$ 时为负。对 $i\notin A(\bar{\boldsymbol{x}})$，$g_i(\bar{\boldsymbol{x}})<0$，由连续性在小 t 时仍为负。缩小 δ 后，$\boldsymbol{x}(t)$ 在 $0\le t<\delta$ 时可行。

约束函数二阶连续可微时，隐函数的导数公式

$$\boldsymbol{w}'(t)=-\big[\boldsymbol{D}_{\boldsymbol{w}}\Phi(t,\boldsymbol{w}(t))\big]^{-1}\boldsymbol{D}_t\Phi(t,\boldsymbol{w}(t))$$

的右端沿解连续可微，所以 $\boldsymbol{w}$ 二阶连续可微，曲线也是。 ■

圆周上可以把这个构造完全算出来。$\bar{\boldsymbol{x}}=(1,0)$，$\boldsymbol{d}=(0,1)$，$\boldsymbol{J}=(2,0)$，修正方程是

$$(1+2w)^2+t^2=1.$$

取 $w(0)=0$ 的解支，得到

$$w(t)=\frac{\sqrt{1-t^2}-1}{2}=-\frac{t^2}{4}+o(t^2),\qquad \boldsymbol{x}(t)=\big(\sqrt{1-t^2},\,t\big).$$

修正量 w 是 t 的二阶小量，这正是 $w'(0)=0$ 的含义。图 17.12画出 $t=0.3,0.55,0.8$ 时的切线步和修正，修正量随 t 减小而更快地消失。

17.1 约束问题
17.2 可行变化
17.3 约束资格
17.3.1 线性无关约束资格
17.3.2 Mangasarian–Fromovitz 条件
17.4 乘子条件
17.5 二阶条件
17.6 本章小结

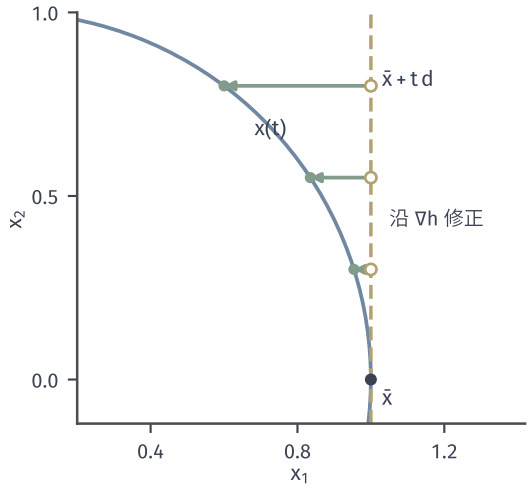


图 17.12 用隐函数定理修正线性化方向。蓝线是单位圆周，黄色虚线是切线 $\bar{\boldsymbol{x}} + t\boldsymbol{d}$，黄色空心点是不可行的试探点。绿色箭头沿 $\nabla h(\bar{\boldsymbol{x}})$ 方向把试探点拉回圆周，绿点组成可行曲线 $\boldsymbol{x}(t)$。t 越小，修正量相对 t 越小。

有了可行曲线，线性化方向就全部是真实方向。

定理 17.10 LICQ 下线性化准确 设约束函数在 $\bar{\boldsymbol{x}} \in \boldsymbol{C}$ 附近连续可微，$\bar{\boldsymbol{x}}$ 满足 LICQ。则

$$\boldsymbol{T}_{\boldsymbol{C}}(\bar{\boldsymbol{x}}) = \boldsymbol{F}(\bar{\boldsymbol{x}}). \tag{17.15}$$

证明 包含 $\subseteq$ 是定理 17.7。反过来取 $\boldsymbol{d} \in \boldsymbol{F}(\bar{\boldsymbol{x}})$，令

$$W = \{i \in A(\bar{\boldsymbol{x}}) : \langle \nabla g_i(\bar{\boldsymbol{x}}), \boldsymbol{d} \rangle = 0\}.$$

LICQ 保证引理 17.9的线性无关假设成立，得到可行曲线。取 $t_k = \delta/(k+1)$，$\boldsymbol{x}^{(k)} = \boldsymbol{x}(t_k)$，由 $\boldsymbol{x}'(0) = \boldsymbol{d}$ 知式 (17.7)成立，所以 $\boldsymbol{d}$ 是切向量。 ■

条件与约束的写法有关 LICQ 是对约束函数的要求，不是对集合的要求。把预算约束 $x_1 + x_2 \le \tau$ 写两遍，可行集一点没变，切锥也没变，但活动梯度 $(1,1)$ 出现两次，线性相关，LICQ 就不成立了，见图 17.11(b)。这说明 LICQ 可以因为写法上的冗余而失败，并不代表集合本身有什么毛病。下一小节的条件能容忍这种冗余。

17.3.2 Mangasarian–Fromovitz 条件

回头看证明，线性化准确真正需要什么？对活动不等式来说，严格向内的方向不必拉回，因为它们本来就有一阶余量。只有等式约束要靠拉回来保

持。所以只需要等式约束可以被独立修正，并且存在一个同时严格改善所有活动不等式的方向。

定义 17.11 Mangasarian–Fromovitz 约束资格 设 $\bar{\boldsymbol{x}} \in \boldsymbol{C}$。若 $\nabla h_j(\bar{\boldsymbol{x}})$（$j = 1, \dots, p$）线性无关，并且存在 $\bar{\boldsymbol{d}} \in \mathbb{R}^n$，使

$$\begin{aligned} \langle \nabla h_j(\bar{\boldsymbol{x}}), \bar{\boldsymbol{d}} \rangle &= 0, \quad j = 1, \dots, p, \\ \langle \nabla g_i(\bar{\boldsymbol{x}}), \bar{\boldsymbol{d}} \rangle &< 0, \quad i \in A(\bar{\boldsymbol{x}}), \end{aligned} \tag{17.16}$$

就称 $\bar{\boldsymbol{x}}$ 满足Mangasarian–Fromovitz约束资格(Mangasarian–Fromovitz constraint qualification，MFCQ)。

条件的两部分各有用途：等式梯度线性无关让我们能用隐函数定理保持等式；方向 $\bar{\boldsymbol{d}}$ 让我们能严格走进不等式的内部。图 17.13(a) 中三条活动梯度在平面内必然线性相关，LICQ 不成立，但它们都落在某个开半平面内，绿色的 $\bar{\boldsymbol{d}}$ 同时与三者成钝角，MFCQ 成立。图 (b) 是尖点：要求 $\bar{d}_2 < 0$ 与 $-\bar{d}_2 < 0$，两个开半平面不相交，这样的方向不存在。

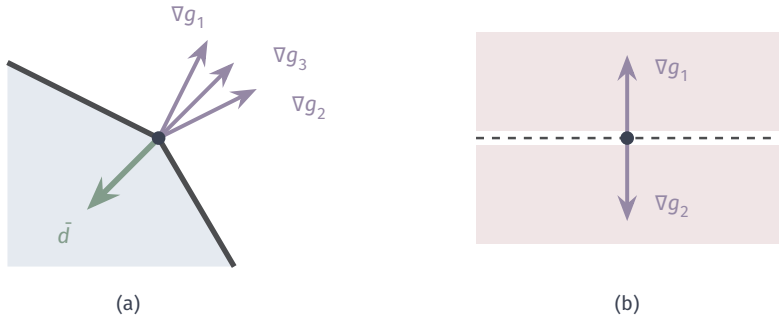


图 17.13 MFCQ 要求存在严格向内的方向。(a) 三条活动约束的梯度（紫色）线性相关，但绿色方向 $\bar{\boldsymbol{d}}$ 与三者都成钝角，MFCQ 成立。(b) 两个活动梯度方向相反，使约束严格减小的方向分别在上下两个开半平面（浅红）里，两者不相交，MFCQ 不成立。

两个条件之间有蕴含关系，但不等价。

引理 17.12 LICQ 蕴含 MFCQ 若 $\bar{\boldsymbol{x}}$ 满足 LICQ，则 $\bar{\boldsymbol{x}}$ 满足 MFCQ。

证明 以 $\nabla h_j(\bar{\boldsymbol{x}})$ 和活动的 $\nabla g_i(\bar{\boldsymbol{x}})$ 作行组成矩阵 $\boldsymbol{J}$，LICQ 说明 $\boldsymbol{J}$ 行满秩，所以 $\boldsymbol{J}\boldsymbol{J}^{\top}$ 可逆。令 $\boldsymbol{b}$ 是等式对应分量为 0、不等式对应分量为 -1 的向量，取

$$\bar{\boldsymbol{d}} = \boldsymbol{J}^{\top}(\boldsymbol{J}\boldsymbol{J}^{\top})^{-1}\boldsymbol{b},$$

则 $J\bar{\boldsymbol{d}} = \boldsymbol{b}$，这正是式 (17.16)。等式梯度作为线性无关组的子集仍线性无关。 ■

反向不成立。把预算约束写两遍，活动梯度是两个 $(1,1)$，LICQ 失败；取 $\bar{\boldsymbol{d}} = (-1,-1)$，内积都是 $-2 < 0$，MFCQ 成立。

定理 17.13　MFCQ 下线性化准确　设约束函数在 $\bar{\boldsymbol{x}} \in \boldsymbol{C}$ 附近连续可微，$\bar{\boldsymbol{x}}$ 满足 MFCQ。则式 (17.15)成立。

证明　只需证 $\boldsymbol{F} \subseteq \boldsymbol{T}_{\boldsymbol{C}}$。取 $\boldsymbol{d} \in \boldsymbol{F}(\bar{\boldsymbol{x}})$，对 $\epsilon > 0$ 令 $\boldsymbol{d}_\epsilon = \boldsymbol{d} + \epsilon\bar{\boldsymbol{d}}$。由式 (17.16)，

$$\langle \nabla h_j(\bar{\boldsymbol{x}}), \boldsymbol{d}_\epsilon \rangle = 0, \qquad \langle \nabla g_i(\bar{\boldsymbol{x}}), \boldsymbol{d}_\epsilon \rangle < 0, \quad i \in A(\bar{\boldsymbol{x}}).$$

取 $W = \varnothing$，引理 17.9的线性无关假设此时只要求等式梯度线性无关，这由 MFCQ 保证。于是沿 $\boldsymbol{d}_\epsilon$ 有可行曲线，$\boldsymbol{d}_\epsilon \in \boldsymbol{T}_{\boldsymbol{C}}(\bar{\boldsymbol{x}})$。由引理 17.2，切锥闭，令 $\epsilon \downarrow 0$ 得到 $\boldsymbol{d} \in \boldsymbol{T}_{\boldsymbol{C}}(\bar{\boldsymbol{x}})$。 ■

这里“先扰动成严格方向，再取极限”这一步是 MFCQ 证明的关键，它绕开了 LICQ 需要的全部活动梯度线性无关。

仿射约束与条件的边界　还有一类不需要任何检查的约束：若全部活动约束和等式约束都是仿射函数，$\boldsymbol{d} \in \boldsymbol{F}(\bar{\boldsymbol{x}})$ 时直接有 $\bar{\boldsymbol{x}} + t\boldsymbol{d}$ 在小 $t > 0$ 下可行，因此 $\boldsymbol{T}_{\boldsymbol{C}} = \boldsymbol{F}$。这正是线性规划不需要讨论约束资格的原因。

约束资格是充分条件，不是线性化准确的必要条件。表 17.2用同一个集合 $\{0\}$ 的三种写法说明这一点。第三行 LICQ 和 MFCQ 都不成立，线性化却是准确的，它属于上面的仿射情形。

约束写法	$\boldsymbol{F}(0)$	LICQ	MFCQ	$\boldsymbol{T} = \boldsymbol{F}$
$x = 0$	$\{0\}$	成立	成立	是
$x^2 \le 0$	$\mathbb{R}$	不成立	不成立	否
$x \le 0,\ -x \le 0$	$\{0\}$	不成立	不成立	是

表 17.2　同一可行集 $\{0\}$ 的三种写法。切锥恒为 $\{0\}$，线性化锥与约束资格随写法改变。

全节的结论可以连成一条链：

$$\text{LICQ} \implies \text{MFCQ} \implies \boldsymbol{T}_{\boldsymbol{C}} = \boldsymbol{F}.$$

17.1 约束问题
17.2 可行变化
17.3 约束资格
17.4 乘子条件
17.4.1 等式约束的 Lagrange 乘子
17.4.2 不等式约束的 KKT 条件
17.4.3 乘子的存在与唯一性
17.4.4 凸问题的全局判别
17.5 二阶条件
17.6 本章小结

有了最后这个等式，切锥上的必要条件就可以放到线性化锥上检验，下一节由此得到关于梯度的方程。

17.4 乘子条件

到目前为止，局部最小点的必要条件是“线性化锥中没有下降方向”，前提是线性化准确。这句话要对无穷多个方向逐一检验，不便于计算。接下来要弄清：怎样把它改写成有限个关于梯度的方程？先看只有等式约束的情形，再加入不等式，最后回答这组方程何时必要、何时充分。

17.4.1 等式约束的 Lagrange 乘子

下面的问题足够小，可以用三种办法解，比较它们就能看出乘子从哪里来：

$$\min_{\boldsymbol{x}\in\mathbb{R}^2}\ \frac{1}{2}(x_1^2+4x_2^2)\quad \text{s.t.}\quad x_1+x_2=1. \tag{17.17}$$

第一种办法：消去约束 可行集是一条直线，用参数 s 表示为 $\boldsymbol{x}(s)=(1-s,s)$。把它代入目标，就成了无约束的一元问题：

$$\phi(s)=\frac{1}{2}\big[(1-s)^2+4s^2\big],\qquad \phi'(s)=5s-1.$$

令导数为零，得 $s=1/5$。于是

$$\boldsymbol{x}^\star=\Big(\frac{4}{5},\frac{1}{5}\Big),\qquad f^\star=\frac{1}{2}\Big(\frac{16}{25}+\frac{4}{25}\Big)=\frac{2}{5}.$$

$\phi''=5>0$，这是一元凸二次函数的最小点，所以 $\boldsymbol{x}^\star$ 是全局最小点。

第二种办法：切向导数为零 由链式法则，$\phi'(s)$ 就是梯度沿直线方向 $\boldsymbol{v}=(-1,1)$ 的方向导数：

$$\phi'(s)=\langle\nabla f(\boldsymbol{x}(s)),\boldsymbol{v}\rangle=-x_1+4x_2.$$

令它为零，再加上 $x_1+x_2=1$，解出同样的点。这说明最优点的条件是：梯度在约束直线的切向上没有分量。

第三种办法：梯度平行于法向 切向分量为零，就是说梯度垂直于直线，也就是平行于约束的法向 $\nabla h=(1,1)$。在 $\boldsymbol{x}^\star$ 处，

$$\nabla f(\boldsymbol{x}^\star)=\Big(\frac{4}{5},\frac{4}{5}\Big)=\frac{4}{5}\,\nabla h(\boldsymbol{x}^\star).$$

把这个比例系数写成 $-\nu$，关系就成了 $\nabla f+\nu\nabla h=\boldsymbol{0}$，这里 $\nu=-4/5$。这个系数称为Lagrange 乘子（Lagrange multiplier）。

反过来也能从方程解。未知量是 x_1, x_2, ν，方程是

$$x_1 + \nu = 0, \qquad 4x_2 + \nu = 0, \qquad x_1 + x_2 = 1.$$

前两式给出 $x_1 = -\nu$，$x_2 = -\nu/4$，代入第三式得 $-\frac{5}{4}\nu = 1$，于是 $\nu = -4/5$，点仍是 $(4/5, 1/5)$。这个方程组对任意光滑问题都能写出来，不需要先把约束参数化。

图 17.14(a) 是这件事的几何。最优点处直线与一条等高线相切，所以两者法向平行。在非最优的可行点 $\bar{\boldsymbol{x}} = (0.2, 0.8)$，梯度 $(0.2, 3.2)$ 不垂直于直线，它沿 $\boldsymbol{v}$ 的分量给出 $\phi'(0.8) = 3$，与图 (b) 中的斜率相同，反向移动（绿色箭头）就能下降。

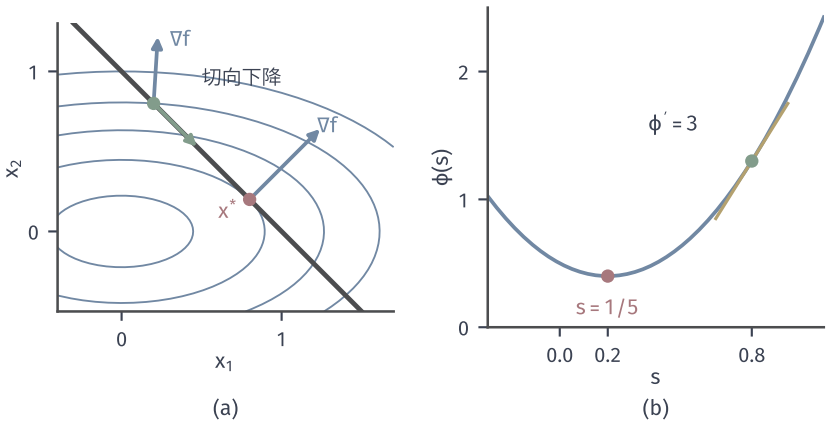


图 17.14　等式约束问题 (17.17)的切点条件。(a) 蓝线是目标的等高线，深灰线是约束直线。红点 $\boldsymbol{x}^\star = (4/5, 1/5)$ 处直线与等高线相切，梯度沿法向。绿点 $(0.2, 0.8)$ 处梯度有切向分量，绿色箭头是沿直线的下降方向。(b) 目标沿直线的限制 $\phi(s) = f(1-s, s)$，红点是最小点 $s = 1/5$，绿点 $s = 0.8$ 处的切线（黄色）斜率为 3。

一般的等式约束情形完全一样，只是切向从一条线变成一个子空间。

定理 17.14　等式约束的一阶必要条件　考虑只有等式约束的问题 (17.2)（$m = 0$）。设 f、h_j 在局部最小点 $\boldsymbol{x}^\star$ 附近连续可微，$\nabla h_1(\boldsymbol{x}^\star), \dots, \nabla h_p(\boldsymbol{x}^\star)$ 线性无关。则存在唯一的 $\boldsymbol{\nu}^\star \in \mathbb{R}^p$，使

$$\nabla f(\boldsymbol{x}^\star) + \sum_{j=1}^{p} \nu_j^\star \nabla h_j(\boldsymbol{x}^\star) = \boldsymbol{0}. \tag{17.18}$$

17.1 约束问题
17.2 可行变化
17.3 约束资格
17.4 乘子条件
17.4.1 等式约束的 Lagrange 乘子
17.4.2 不等式约束的 KKT 条件
17.4.3 乘子的存在与唯一性
17.4.4 凸问题的全局判别
17.5 二阶条件
17.6 本章小结

证明 以 $\nabla h_j(\boldsymbol{x}^\star)^\top$ 为行组成矩阵 $\boldsymbol{E}$。由定理 17.10，切锥等于线性化锥。这里线性化锥就是 $\boldsymbol{E}$ 的零空间，是一个子空间。

由定理 17.3，对这个子空间中的 $\boldsymbol{d}$ 有 $\langle \nabla f(\boldsymbol{x}^\star), \boldsymbol{d}\rangle \geq 0$。$-\boldsymbol{d}$ 也在子空间内，所以内积只能为零，即 $\nabla f(\boldsymbol{x}^\star)$ 与 $\boldsymbol{E}$ 的零空间正交。

零空间的正交补是 $\boldsymbol{E}^\top$ 的值域，所以存在 $\boldsymbol{u}$ 使 $\nabla f(\boldsymbol{x}^\star) = \boldsymbol{E}^\top \boldsymbol{u}$，令 $\boldsymbol{\nu}^\star = -\boldsymbol{u}$ 即得式 (17.18)。唯一性来自 $\boldsymbol{E}^\top$ 的列线性无关。 ■

把目标和约束按乘子加权相加，定义Lagrange 函数（Lagrangian）

$$\mathcal{L}(\boldsymbol{x}, \boldsymbol{\nu}) = f(\boldsymbol{x}) + \sum_{j=1}^{p} \nu_j h_j(\boldsymbol{x}). \tag{17.19}$$

式 (17.18)就是 $\nabla_{\boldsymbol{x}} \mathcal{L} = \boldsymbol{0}$ 在 $(\boldsymbol{x}^\star, \boldsymbol{\nu}^\star)$ 处成立，可行性 $h_j = 0$ 就是 $\nabla_{\boldsymbol{\nu}} \mathcal{L} = \boldsymbol{0}$。约束问题的一阶条件由此写成了无约束形式的驻定方程。要注意，这只是驻定，$\mathcal{L}$ 在 $\boldsymbol{x}^\star$ 不必取最小值，更不是在 $(\boldsymbol{x}, \boldsymbol{\nu})$ 上取最小值。

乘子还有一层经济含义。把例子的约束放松成 $x_1 + x_2 = 1 + \varepsilon$，同样的计算给出最优值 $\frac{2}{5}(1+\varepsilon)^2$，它在 $\varepsilon = 0$ 处的导数是 $4/5 = -\nu$。所以 $|\nu|$ 是约束右端变动一个单位时最优值的变化率，这叫影子价格。这里只是在一个例子上观察，一般结论和条件由第 19章讨论。

17.4.2 不等式约束的 KKT 条件

等式约束的切向是子空间，$\boldsymbol{d}$ 和 $-\boldsymbol{d}$ 都能走，所以乘子的符号不受限制。不等式只限制朝外的一侧，切向变成了锥，乘子应该带上符号。先用预算例看看符号是怎么来的。

力的平衡 把 $-\nabla f$ 想成目标施加在点上的拉力，把活动约束想成一堵墙。墙只能把点往内推，不能把点往外拉，第 i 堵墙的推力沿内法向，写成 $-\lambda_i \nabla g_i$，其中 $\lambda_i \geq 0$ 是推力大小。不活动的约束碰不到点，推力为零。点在最优位置保持不动，意味着合力为零：

$$-\nabla f(\boldsymbol{x}^\star) = \sum_{i \in A(\boldsymbol{x}^\star)} \lambda_i \nabla g_i(\boldsymbol{x}^\star), \qquad \lambda_i \geq 0. \tag{17.20}$$

这个类比只解释一阶平衡，它不涉及动力学或曲率。等式约束是两面都有墙的轨道，推力可正可负，所以乘子不限号。

图 17.15算了两个例子。$\tau = 2$ 时只有预算线活动，$-\nabla f = (1/2, 1/2)$，一堵墙就够了：$\lambda_1 = 1/2$。$\tau = 1/2$ 时最优点在角点，两堵墙合力，由

$$\left(\frac{3}{2}, 1\right) = \lambda_1 (1, 1) + \lambda_3 (0, -1)$$

解出 $\lambda_1 = 3/2$，$\lambda_3 = 1/2$，都非负。

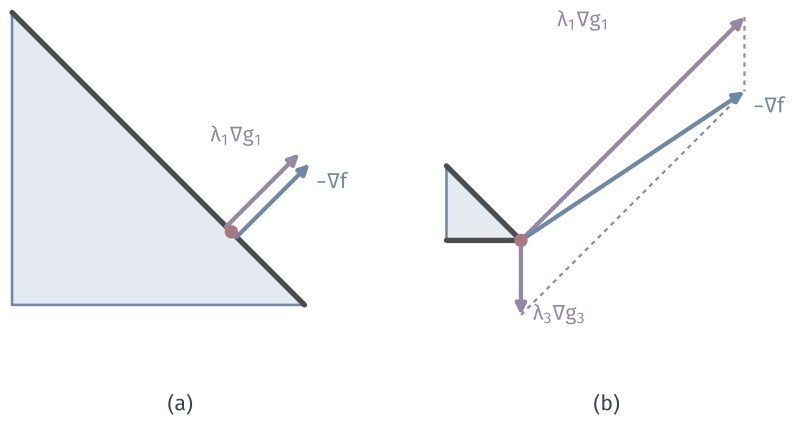


图 17.15　最优点处的力的平衡。蓝色箭头是负梯度，紫色箭头是 $\lambda_i \nabla g_i$。(a)$\tau = 2$：$-\nabla f = \frac{1}{2}\nabla g_1$（两箭头实际重合，为看清而错开绘制）。(b)$\tau = 1/2$：$-\nabla f = \frac{3}{2}\nabla g_1 + \frac{1}{2}\nabla g_3$，虚线组成平行四边形。

从无下降方向到乘子　力的平衡是直观，严格的推导要用第 2章的 Farkas 引理：对矩阵 $\boldsymbol{M}$ 和向量 $\boldsymbol{b}$，系统 $\boldsymbol{M}\boldsymbol{u} = \boldsymbol{b}$，$\boldsymbol{u} \geq \boldsymbol{0}$ 与系统 $\boldsymbol{M}^{\top}\boldsymbol{z} \geq \boldsymbol{0}$，$\boldsymbol{b}^{\top}\boldsymbol{z} < 0$ 恰有一个有解。几何上，$\boldsymbol{b}$ 要么在 $\boldsymbol{M}$ 的列张成的锥内，要么能被一个超平面与锥隔开。

引理 17.15　无线性化下降方向与乘子　设 $\bar{\boldsymbol{x}} \in \boldsymbol{C}$，$f$ 与约束函数在 $\bar{\boldsymbol{x}}$ 处可微。不存在 $\boldsymbol{d} \in \boldsymbol{F}(\bar{\boldsymbol{x}})$ 使 $\langle \nabla f(\bar{\boldsymbol{x}}), \boldsymbol{d} \rangle < 0$，当且仅当存在 $\lambda_i \geq 0$ $(i \in A(\bar{\boldsymbol{x}}))$ 和 $\nu_j \in \mathbb{R}$，使

$$\nabla f(\bar{\boldsymbol{x}}) + \sum_{i \in A(\bar{\boldsymbol{x}})} \lambda_i \nabla g_i(\bar{\boldsymbol{x}}) + \sum_{j=1}^{p} \nu_j \nabla h_j(\bar{\boldsymbol{x}}) = \boldsymbol{0}. \tag{17.21}$$

证明　以活动的 $\nabla g_i(\bar{\boldsymbol{x}})^{\top}$ 为行组成 $\boldsymbol{B}$，以 $\nabla h_j(\bar{\boldsymbol{x}})^{\top}$ 为行组成 $\boldsymbol{E}$，在 Farkas 引理中取

$$\boldsymbol{M} = \begin{bmatrix} \boldsymbol{B}^{\top} & \boldsymbol{E}^{\top} & -\boldsymbol{E}^{\top} \end{bmatrix}, \qquad \boldsymbol{b} = -\nabla f(\bar{\boldsymbol{x}}).$$

把等式乘子拆成 $\boldsymbol{\nu} = \boldsymbol{\nu}^{+} - \boldsymbol{\nu}^{-}$，两部分都非负，并记

$$\boldsymbol{u} = (\boldsymbol{\lambda}_A, \boldsymbol{\nu}^{+}, \boldsymbol{\nu}^{-}) \geq \boldsymbol{0},$$

其中 $\boldsymbol{\lambda}_A$ 是活动约束的乘子。方程 $\boldsymbol{M}\boldsymbol{u} = \boldsymbol{b}$ 正是式 (17.21)。

另一个系统要求 $\boldsymbol{B}\boldsymbol{z} \geq \boldsymbol{0}$，$\boldsymbol{E}\boldsymbol{z} = \boldsymbol{0}$，$\langle \nabla f(\bar{\boldsymbol{x}}), \boldsymbol{z} \rangle > 0$。令 $\boldsymbol{d} = -\boldsymbol{z}$，它等价于

$$\boldsymbol{B}\boldsymbol{d} \leq \boldsymbol{0}, \qquad \boldsymbol{E}\boldsymbol{d} = \boldsymbol{0}, \qquad \langle \nabla f(\bar{\boldsymbol{x}}), \boldsymbol{d} \rangle < 0,$$

即存在线性化下降方向。Farkas 引理说两个系统恰有一个有解，这就是要证的等价。 ■

图 17.16画出引理的两种情形，两张图的约束梯度相同。(a) 是 $\tau = 1/2$ 的角点，$-\nabla f$ 落在紫色的梯度锥内，乘子存在，绿色的线性化锥与它成钝角，没有下降方向。(b) 是 $\tau = 2$ 时的角点 $(2,0)$，这一点可行但不是最优点。这里 $-\nabla f = (0,1)$ 在锥外。

解驻定方程 $(0,-1) + \lambda_1(1,1) + \lambda_3(0,-1) = \boldsymbol{0}$，得 $\lambda_1 = 0$，$\lambda_3 = -1$，符号不对。负乘子正好指出了下降方向 $\boldsymbol{d} = (-1,1)$，也就是离开 $x_2 = 0$ 这堵墙：

$$f(2-s, s) = \frac{1}{2}\big[s^2 + (1-s)^2\big], \qquad \frac{\mathrm{d}}{\mathrm{d}s} f\Big|_{s=0} = -1 < 0.$$

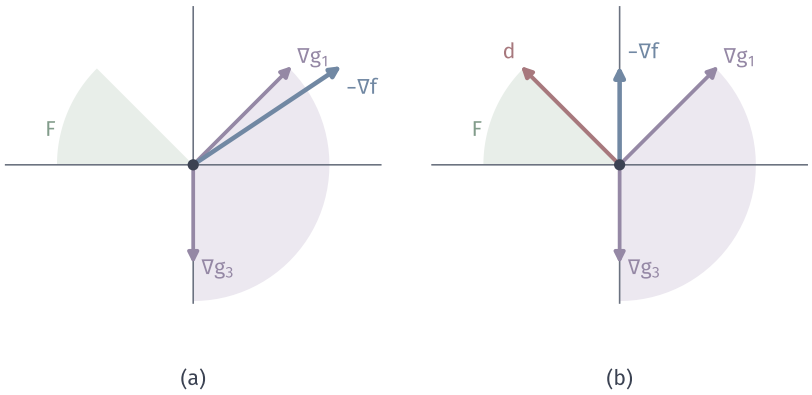


图 17.16 Farkas 引理的两种情形，画在方向空间中。紫色楔形是活动梯度张成的锥，浅绿楔形是线性化锥 $\boldsymbol{F}$，蓝色箭头是 $-\nabla f$。(a)$\tau = 1/2$ 的角点：$-\nabla f = (3/2, 1)$ 在锥内。(b)$\tau = 2$ 的角点 $(2,0)$：$-\nabla f = (0,1)$ 在锥外，红色箭头 $\boldsymbol{d} = (-1,1)$ 在 $\boldsymbol{F}$ 内，与负梯度成锐角，是下降方向。

KKT 条件 式 (17.21)只对活动约束求和。为了不必事先知道哪些约束活动，给每个不等式都配一个乘子，定义完整的 Lagrange 函数

$$\mathcal{L}(\boldsymbol{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}) = f(\boldsymbol{x}) + \sum_{i=1}^{m} \lambda_i g_i(\boldsymbol{x}) + \sum_{j=1}^{p} \nu_j h_j(\boldsymbol{x}), \tag{17.22}$$

并用乘积 $\lambda_i g_i = 0$ 规定“不活动的约束乘子为零”。这样就得到下面四组条件。

定义 17.16　KKT 条件　设 f、g_i、h_j 在 $\boldsymbol{x}^\star$ 处可微。若存在 $\boldsymbol{\lambda}^\star \in \mathbb{R}^m$、$\boldsymbol{\nu}^\star \in \mathbb{R}^p$，使

$$\nabla_{\boldsymbol{x}} \mathcal{L}(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) = \mathbf{0}, \tag{17.23}$$

$$g_i(\boldsymbol{x}^\star) \le 0, \quad h_j(\boldsymbol{x}^\star) = 0, \tag{17.24}$$

$$\lambda_i^\star \ge 0, \tag{17.25}$$

$$\lambda_i^\star g_i(\boldsymbol{x}^\star) = 0, \tag{17.26}$$

对所有 $i = 1, \dots, m$，$j = 1, \dots, p$ 成立，就称 $\boldsymbol{x}^\star$ 满足KKT 条件（Karush–Kuhn–Tucker conditions），$(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 称为KKT 点（KKT point），$(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 称为 KKT 乘子。

表 17.3列出四组条件的分工。其中式 (17.26)称为互补松弛，它把活动集的选择藏进了乘积里。

条件	式子	作用
驻定	(17.23)	负梯度被约束的法向组合抵消
原始可行	(17.24)	候选点满足全部约束
乘子非负	(17.25)	墙只能推不能拉
互补松弛	(17.26)	不活动约束不出力

表 17.3　KKT 条件的四个组成部分。

预算例的计算　互补松弛把求解变成对活动集的枚举：猜一个活动集，令其余乘子为零，解方程，再检查可行性和符号。预算例的驻定条件是

$$x_1 - 2 + \lambda_1 - \lambda_2 = 0, \qquad x_2 - 1 + \lambda_1 - \lambda_3 = 0.$$

取 $\tau = 2$。先猜没有活动约束，三个乘子都是零，得 $\boldsymbol{x} = (2, 1)$，但 $g_1 = 1 > 0$，不可行。再猜只有 g_1 活动，$\lambda_2 = \lambda_3 = 0$，$x_1 + x_2 = 2$，由驻定条件得 $x_1 = 2 - \lambda_1$，$x_2 = 1 - \lambda_1$，代入得

$$3 - 2\lambda_1 = 2, \qquad \lambda_1 = \frac{1}{2}, \qquad \boldsymbol{x} = \Big(\frac{3}{2}, \frac{1}{2}\Big).$$

这一点可行，乘子非负，KKT 条件全部成立。

取 $\tau = 1/2$。只有 g_1 活动时解出 $\lambda_1 = 5/4$，$\boldsymbol{x} = (3/4, -1/4)$，不可行。再猜 g_1, g_3 活动，$x_2 = 0$，$x_1 = 1/2$，由第一个驻定方程得 $\lambda_1 = 3/2$，第二个得 $\lambda_3 = \lambda_1 - 1 = 1/2$。全部条件成立。

17.1 约束问题
17.2 可行变化
17.3 约束资格
17.4 乘子条件
17.4.1 等式约束的 Lagrange 乘子
17.4.2 不等式约束的 KKT 条件
17.4.3 乘子的存在与唯一性
17.4.4 凸问题的全局判别
17.5 二阶条件
17.6 本章小结

让 τ 连续变化，结果分三段：

$$(\boldsymbol{x}^\star, \lambda_1, \lambda_3) = \begin{cases} \big((\tau, 0),\ 2-\tau,\ 1-\tau\big), & 0 < \tau \le 1, \\ \big(\big(\frac{1+\tau}{2}, \frac{\tau-1}{2}\big),\ \frac{3-\tau}{2},\ 0\big), & 1 \le \tau \le 3, \\ \big((2,1),\ 0,\ 0\big), & \tau \ge 3, \end{cases} \tag{17.27}$$

三段都有 $\lambda_2 = 0$。图 17.17画出最优点的轨迹和乘子曲线。

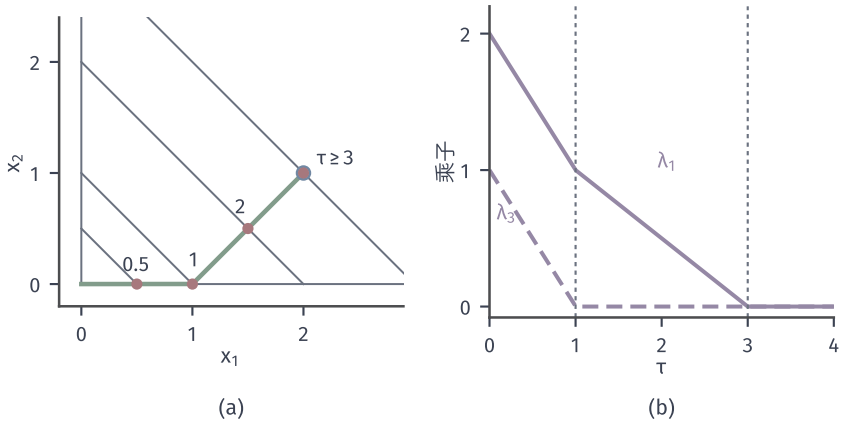


图 17.17 预算例的解随 τ 变化。(a) 绿线是最优点轨迹，深灰细线是预算线 $x_1 + x_2 = \tau$，红点对应 $\tau = 0.5, 1, 2, 3$，空心点是 $\boldsymbol{c}$。(b) 乘子 λ_1（实线）与 λ_3（虚线），竖直虚线是活动集改变的位置 $\tau = 1, 3$。

这个例子说清了互补松弛的方向。$\lambda_i > 0$ 推出约束活动，但约束活动推不出 $\lambda_i > 0$。$\tau = 3$ 时预算线恰好经过 $\boldsymbol{c}$，g_1 活动，而 $\lambda_1 = 0$：预算恰好够用，这堵墙碰到了点却不用出力。$\tau = 1$ 时最优点是角点 $(1, 0)$，g_3 活动，$\lambda_3 = 0$，同样如此。

从公式 (17.27)还能再次看到影子价格。$1 \le \tau \le 3$ 时最优值是 $(3-\tau)^2/4$，它对 τ 的导数是 $-(3-\tau)/2 = -\lambda_1$：多一块钱，目标改善 λ_1。

17.4.3 乘子的存在与唯一性

前面的推导把各步准备好了，现在把它们合起来。

定理 17.17 KKT 条件的必要性 设 f、g_i、h_j 在局部最小点 $\boldsymbol{x}^\star$ 附近连续可微。若 $\boldsymbol{x}^\star$ 满足 MFCQ，则存在 KKT 乘子 $(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$，并且全体 KKT 乘子组成有界集合。若 $\boldsymbol{x}^\star$ 满足 LICQ，则 KKT 乘子唯一。

证明 存在性。由定理 17.13，切锥等于线性化锥。由定理 17.3，$\boldsymbol{F}(\boldsymbol{x}^\star)$ 中没有使 $\langle \nabla f(\boldsymbol{x}^\star), \boldsymbol{d}\rangle < 0$ 的方向。引理 17.15给出活动约束的乘子与 $\boldsymbol{\nu}^\star$。不活动约束的乘子取零，四组条件全部成立。

有界性。若乘子列 $(\boldsymbol{\lambda}^{(k)}, \boldsymbol{\nu}^{(k)})$ 的范数趋于无穷，把驻定方程除以这个范数，取收敛子列，极限 $(\bar{\boldsymbol{\lambda}}, \bar{\boldsymbol{\nu}})$ 的范数为 1，满足 $\bar{\boldsymbol{\lambda}} \geq \mathbf{0}$，不活动分量为零，并且

$$\sum_{i \in A(\boldsymbol{x}^\star)} \bar{\lambda}_i \nabla g_i(\boldsymbol{x}^\star) + \sum_{j=1}^{p} \bar{\nu}_j \nabla h_j(\boldsymbol{x}^\star) = \mathbf{0}.$$

把上式与 MFCQ 的方向 $\bar{\boldsymbol{d}}$ 作内积，等式项消失，得到

$$\sum_{i \in A(\boldsymbol{x}^\star)} \bar{\lambda}_i \langle \nabla g_i(\boldsymbol{x}^\star), \bar{\boldsymbol{d}}\rangle = 0.$$

每项都非正，而内积严格为负，所以 $\bar{\boldsymbol{\lambda}} = \mathbf{0}$。剩下的等式项由 ∇h_j 线性无关推出 $\bar{\boldsymbol{\nu}} = \mathbf{0}$，与范数为 1 矛盾。

唯一性。设有两组 KKT 乘子。不活动分量都是零，两个驻定方程相减，得到活动梯度和等式梯度的一个线性组合等于零，系数是两组乘子之差。LICQ 说明系数全为零。 ■

由引理 17.12，LICQ 下存在性自动成立。全部活动约束与等式约束都是仿射函数时，$\boldsymbol{T_C} = \boldsymbol{F}$ 不需要任何资格，乘子同样存在，只是有界性和唯一性不再有保证。

存在与唯一是两回事 图 17.18对比几种情形的乘子集合。把预算线写两遍（$\tau = 2$），MFCQ 成立，驻定条件只约束 $\lambda_1 + \lambda_1'$ 的和，$\lambda_1 + \lambda_1' = 1/2$ 是一条线段：乘子存在、有界，但不唯一。

再看在 $\{0\}$ 上最小化 x。写成 $x \leq 0, -x \leq 0$ 时，驻定方程是 $1+\lambda_1-\lambda_2 = 0$，解集是无界射线，MFCQ 不成立时有界性确实可能失去。写成 $x = 0$ 时，$\nu = -1$ 是唯一乘子。

没有乘子的最小点 第三种写法最值得注意。最小化 x，约束 $g(x) = x^2 \leq 0$。可行集只有原点，所以 $x^\star = 0$ 是全局最小点。驻定方程是

$$1 + \lambda \cdot 2x^\star = 1 = 0,$$

对任何 λ 都无解，图 17.18(c) 的残差恒为 1。这是一个没有 KKT 乘子的最小点。

17.1 约束问题
17.2 可行变化
17.3 约束资格
17.4 乘子条件
17.4.1 等式约束的 Lagrange 乘子
17.4.2 不等式约束的 KKT 条件
17.4.3 乘子的存在与唯一性
17.4.4 凸问题的全局判别
17.5 二阶条件
17.6 本章小结

因此，不能仅凭驻定方程无解就排除一个候选点，除非已经确认它满足约束资格。这里的问题出在约束函数的写法上，$\nabla g(0)=0$ 让约束的一阶信息完全失效，与目标函数无关。

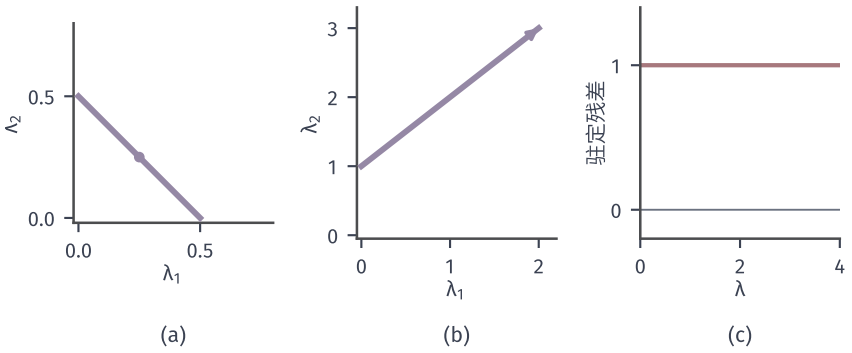


图 17.18 KKT 乘子集合的三种情况。(a) 预算线写两遍（$\tau=2$），乘子集合是线段 $\lambda_1+\lambda_2=1/2$（这里 λ_2 表示重复约束的乘子），有界而不唯一。(b)$\min x$，约束 $x\le 0$，$-x\le 0$：乘子集合是无界射线 $\lambda_2=1+\lambda_1$。(c)$\min x$，约束 $x^2\le 0$：对任何乘子，驻定残差都等于 1，乘子不存在。

17.4.4 凸问题的全局判别

KKT 条件在约束资格下是必要的，它能筛掉不合格的点，却不能确认合格的点就是最小点。什么时候能反过来？答案是问题凸的时候，而且这时连约束资格都不用检查。

定理 17.18 凸问题的 KKT 充分性 设 $\boldsymbol{D}\subseteq\mathbb{R}^n$ 是包含可行集的开凸集，f 与 g_i 在 $\boldsymbol{D}$ 上凸且可微，h_j 是仿射函数。若 $(\boldsymbol{x}^\star,\boldsymbol{\lambda}^\star,\boldsymbol{\nu}^\star)$ 是 KKT 点，则 $\boldsymbol{x}^\star$ 是问题 (17.2)的全局最小点。

证明 任取可行点 $\boldsymbol{x}$，记 $\boldsymbol{u}=\boldsymbol{x}-\boldsymbol{x}^\star$。由第 1章的一阶支撑不等式，凸函数 f 满足

$$f(\boldsymbol{x})\ge f(\boldsymbol{x}^\star)+\langle\nabla f(\boldsymbol{x}^\star),\boldsymbol{u}\rangle.$$

再由驻定条件 (17.23)，把梯度替换掉：

$$f(\boldsymbol{x})\ge f(\boldsymbol{x}^\star)-\sum_{i=1}^{m}\lambda_i^\star\langle\nabla g_i(\boldsymbol{x}^\star),\boldsymbol{u}\rangle-\sum_{j=1}^{p}\nu_j^\star\langle\nabla h_j(\boldsymbol{x}^\star),\boldsymbol{u}\rangle.$$

h_j 仿射，$\boldsymbol{x}$ 与 $\boldsymbol{x}^\star$ 都可行，所以

$$\langle\nabla h_j(\boldsymbol{x}^\star),\boldsymbol{u}\rangle=h_j(\boldsymbol{x})-h_j(\boldsymbol{x}^\star)=0,$$

最后一个和式消失。

对 $\lambda_i^\star = 0$ 的项，这一项本来就是零。对 $\lambda_i^\star > 0$ 的项，互补松弛给出 $g_i(\boldsymbol{x}^\star) = 0$，再对凸函数 g_i 用支撑不等式：

$$\langle \nabla g_i(\boldsymbol{x}^\star), \boldsymbol{u} \rangle \le g_i(\boldsymbol{x}) - g_i(\boldsymbol{x}^\star) = g_i(\boldsymbol{x}) \le 0.$$

所以和式中每一项 $-\lambda_i^\star \langle \nabla g_i, \boldsymbol{u} \rangle$ 都非负，代回得到 $f(\boldsymbol{x}) \ge f(\boldsymbol{x}^\star)$。 ■

证明的每一步都用到了相应的假设：目标凸给出一个全局下界，g_i 凸把梯度内积换成函数值，乘子非负保证不等号的方向，互补松弛消去 $g_i(\boldsymbol{x}^\star)$，等式仿射让等式项消失。

把它用在预算例上。目标凸，约束都是仿射函数，所以式 (17.27)中的点都是全局最小点，这一步不需要再检查什么。

还可以从 Lagrange 函数看这个结论。固定乘子后，$\mathcal{L}(\cdot, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 是凸函数，驻定点就是它的全局最小点。在可行点上 $\mathcal{L} \le f$，在 $\boldsymbol{x}^\star$ 处两者相等，于是目标在 $\boldsymbol{x}^\star$ 被一个碗从下面托住了。图 17.19(a) 取最小化 $(x-2)^2$、约束 $x - 1 \le 0$ 的问题，$x^\star = 1$，$\lambda^\star = 2$，$\mathcal{L}(x, 2) = (x-1)^2 + 1$ 就是紫色的碗，可行域上它在 f 的下方。

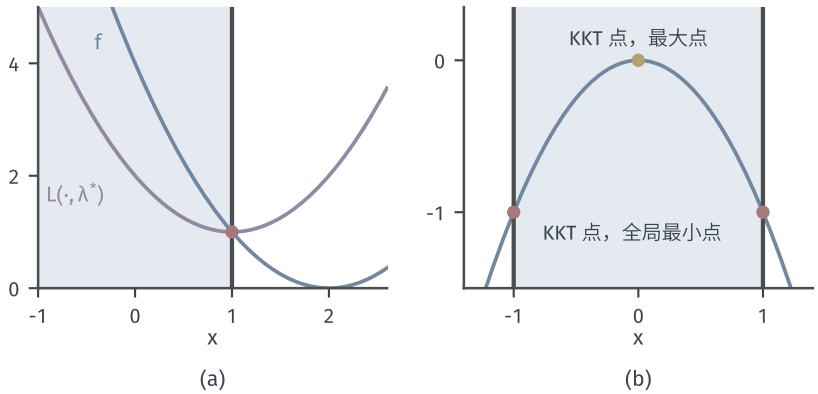


图 17.19 凸与非凸问题中的 KKT 点。浅蓝带是可行域，深灰线是活动约束的位置。(a)$\min (x-2)^2$，$x \le 1$：KKT 点 $x^\star = 1$（红），$\lambda^\star = 2$。紫色曲线 $\mathcal{L}(x, 2) = (x-1)^2 + 1$ 在可行域上位于 f（蓝）下方，并在 $x^\star$ 处与 f 相接。(b)$\min -x^2$，$|x| \le 1$：三个 KKT 点中 $x = 0$（黄）是最大点，$x = \pm 1$（红）是全局最小点。

去掉凸性会怎样 一般非凸问题中，KKT 条件只提供候选。在 $[-1, 1]$ 上最小化 $-x^2$，约束写成 $x - 1 \le 0$，$-x - 1 \le 0$。点 $x = 0$ 没有活动约束，$f'(0) = 0$，乘子取零就满足 KKT 条件，但它是全局最大点。点 $x = 1$ 处由 $-2 + \lambda_1 = 0$ 得 $\lambda_1 = 2$，也满足 KKT 条件，它才是最小点。KKT 方程分不开这两种点，见图 17.19(b)。

17.1 约束问题
17.2 可行变化
17.3 约束资格
17.4 乘子条件
17.5 二阶条件
17.5.1 临界锥
17.5.2 二阶必要条件
17.5.3 二阶充分条件
17.6 本章小结

等式必须是仿射函数也不是多余的要求。单位圆周的 $h(\boldsymbol{x}) = x_1^2 + x_2^2 - 1$ 是凸函数，目标 $\frac{1}{2}\|\boldsymbol{x} - (2,0)\|_2^2$ 也是凸函数，但 $(-1,0)$ 是 KKT 点，却是圆周上的全局最大点。$h = 0$ 的解集不是凸集，定理的证明在处理等式项那一步就失效了。

另外，充分性不提供存在性。$\min x$，$x^2 \le 0$ 是凸问题，最小点却没有 KKT 乘子。表 17.4把必要性与充分性的条件放在一起。

结论方向	所需条件	结论
局部最小 ⇒KKT	MFCQ（或 LICQ、仿射约束）	存在乘子
KKT⇒ 全局最小	目标、g_i 凸，h_j 仿射	不需要约束资格
KKT⇒ 局部最小	一般不成立	需要二阶条件

表 17.4 KKT 条件的必要性与充分性。

17.5 二阶条件

KKT 点可能是最小点，也可能不是。单位圆周上最小化 $\frac{1}{2}\|\boldsymbol{x} - (2,0)\|_2^2$ 就是例子：离 $(2,0)$ 最近和最远的点都满足一阶条件。这就需要回答：一阶信息判断不了的时候，曲率怎样作出判断？这需要先确定该检查哪些方向，再确定该检查谁的曲率。

17.5.1 临界锥

设 $(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 是 KKT 点。对线性化方向 $\boldsymbol{d} \in \boldsymbol{F}(\boldsymbol{x}^\star)$，由驻定条件，目标的一阶变化是

$$\langle \nabla f(\boldsymbol{x}^\star), \boldsymbol{d}\rangle = -\sum_{i \in A(\boldsymbol{x}^\star)} \lambda_i^\star \langle \nabla g_i(\boldsymbol{x}^\star), \boldsymbol{d}\rangle - \sum_{j=1}^{p} \nu_j^\star \langle \nabla h_j(\boldsymbol{x}^\star), \boldsymbol{d}\rangle.$$

等式项为零。每个 $\lambda_i^\star \ge 0$，每个 $\langle \nabla g_i, \boldsymbol{d}\rangle \le 0$，所以右端是非负项之和。

若这个值严格为正，目标沿 $\boldsymbol{d}$ 一阶上升，这个方向已经判决完毕，二阶项不用看。需要继续检查的，只有一阶变化恰好为零的方向。一个非负项之和为零，当且仅当每一项为零，所以这些方向在 $\lambda_i^\star > 0$ 的活动约束上必须取等号。

定义 17.19 临界锥 设 $(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 是 KKT 点。集合

$$\boldsymbol{K}(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star) = \{\boldsymbol{d} \in \boldsymbol{F}(\boldsymbol{x}^\star) : \langle \nabla g_i(\boldsymbol{x}^\star), \boldsymbol{d}\rangle = 0 \text{ 对所有 } \lambda_i^\star > 0\} \quad (17.28)$$

称为**临界锥**（critical cone）。由上面的推导，它等于

$$\boldsymbol{K}(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star) = \{\boldsymbol{d} \in \boldsymbol{F}(\boldsymbol{x}^\star) : \langle \nabla f(\boldsymbol{x}^\star), \boldsymbol{d} \rangle = 0\}. \tag{17.29}$$

式 (17.29)的右端不含乘子，所以即使乘子不唯一，临界锥也不依赖乘子的选择。两种写法各有用处：式 (17.28)便于计算，式 (17.29)说明它的含义。

零乘子的活动约束值得单独看。这样的约束在式 (17.28)里没有被要求取等号，它仍然保留 $\langle \nabla g_i, \boldsymbol{d} \rangle \le 0$ 的单侧限制。所以临界锥一般是锥，不是子空间。

用预算例算三种情况，见图 17.20。$\tau = 1/2$ 的角点，λ_1, λ_3 都为正，两条约束都取等号，$d_1 + d_2 = 0$，$d_2 = 0$，于是 $\boldsymbol{K} = \{\boldsymbol{0}\}$：一阶条件已经判决了所有方向。

$\tau = 1$ 的角点 $(1, 0)$，$\lambda_1 = 1 > 0$，$\lambda_3 = 0$，于是 g_1 取等号，g_3 只保留单侧：

$$\boldsymbol{K} = \{\boldsymbol{d} : d_1 + d_2 = 0,\ d_2 \ge 0\} = \{s(-1, 1) : s \ge 0\}.$$

沿预算线向上走的这一条射线，一阶变化为零，要靠二阶项判断。而反方向 $(1, -1)$ 不可行。

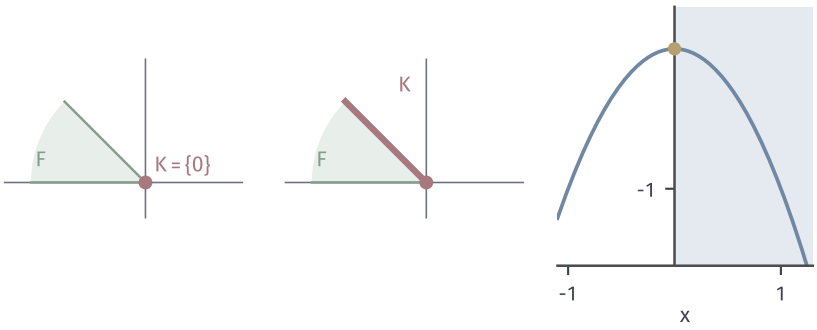


图 17.20　临界锥（红色）与线性化锥 $\boldsymbol{F}$（绿色）。(a) 预算例 $\tau = 1/2$ 的角点，两个乘子都为正，$\boldsymbol{K} = \{\boldsymbol{0}\}$。(b) 预算例 $\tau = 1$ 的角点，$\lambda_3 = 0$，$\boldsymbol{K}$ 是射线 $s(-1, 1)$，$s \ge 0$。(c)$\min -x^2$，$x \ge 0$（蓝色带），黄点 $x = 0$ 是 KKT 点，乘子为零，$\boldsymbol{K} = [0, \infty)$。

不能把活动约束都当成等式　一种常见的简化是把所有活动约束当成等式，对每个活动的 g_i 都要求 $\langle \nabla g_i, \boldsymbol{d} \rangle = 0$。下面的例子说明这样会漏掉下降方向。最小化 $f(x) = -x^2$，约束 $g(x) = -x \le 0$。在 $x = 0$ 处，$f'(0) = 0$，所以 $\lambda = 0$，KKT 条件成立。

17.1 约束问题
17.2 可行变化
17.3 约束资格
17.4 乘子条件
17.5 二阶条件
17.5.1 临界锥
17.5.2 二阶必要条件
17.5.3 二阶充分条件
17.6 本章小结

约束活动而乘子为零，真正的临界锥是 $\{d : -d \le 0\} = [0,\infty)$。沿 $d=1$，$f''(0)d^2 = -2 < 0$，二阶检验发现 $x=0$ 不是局部最小点，事实上 $f(t) = -t^2 < 0$。

要是把约束当成等式，方向只剩 $\{0\}$，就没有方向可供检查，会错误地接受 $x=0$。图 17.20(c) 就是这个例子。

17.5.2 二阶必要条件

下一个问题是该检查谁的曲率。答案不是目标的 Hessian，用下面的例子就能看清。

约束的弯曲进入曲率 在单位圆周上最小化 $f(\boldsymbol{x}) = \frac{1}{2}[(x_1-2)^2 + x_2^2]$，也就是找圆周上离 $(2,0)$ 最近的点。令 $h(\boldsymbol{x}) = x_1^2 + x_2^2 - 1$，驻定条件是

$$x_1 - 2 + 2\nu x_1 = 0, \qquad x_2 + 2\nu x_2 = 0.$$

第二式说明 $x_2 = 0$ 或 $\nu = -1/2$。后者代入第一式得 $-2=0$，不可能，所以 $x_2 = 0$，$x_1 = \pm 1$。两个 KKT 点是

$$(1,0),\ \nu = \frac{1}{2}; \qquad (-1,0),\ \nu = -\frac{3}{2}.$$

这两点的目标 Hessian 都是单位阵，正定，分不开。用角度参数化圆周，目标变成

$$\phi(\theta) = f(\cos\theta, \sin\theta) = \frac{5}{2} - 2\cos\theta, \qquad \phi''(\theta) = 2\cos\theta.$$

在 $(1,0)$ 处 $\phi'' = 2$，是极小；在 $(-1,0)$ 处 $\phi'' = -2$，是极大。图 17.21(b) 的黄色抛物线就是这两个曲率。

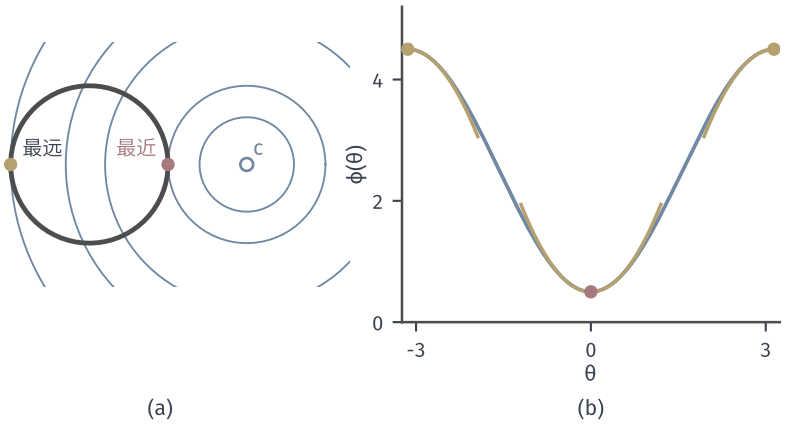


图 17.21 约束的弯曲改变了有效曲率。(a) 深灰圆是可行集，蓝线是目标 $\frac{1}{2}\|\boldsymbol{x}-\boldsymbol{c}\|_2^2$（$\boldsymbol{c}=(2,0)$）的等高线。红点 $(1,0)$ 是最近点，黄点 $(-1,0)$ 是最远点，两者都是 KKT 点，目标 Hessian 都是单位阵。(b) 沿圆周的目标值 $\phi(\theta)=5/2-2\cos\theta$，黄色抛物线是两点处曲率分别为 2、$-2$ 的二次近似。

这两个数从哪里来？沿可行曲线 $\boldsymbol{x}(t)$，$\boldsymbol{x}(0)=\boldsymbol{x}^\star$，$\boldsymbol{x}'(0)=\boldsymbol{d}$，复合函数求二阶导数得到

$$\frac{\mathrm{d}^2}{\mathrm{d}t^2} f(\boldsymbol{x}(t))\Big|_{t=0} = \boldsymbol{d}^\top \nabla^2 f(\boldsymbol{x}^\star)\boldsymbol{d} + \langle \nabla f(\boldsymbol{x}^\star), \boldsymbol{x}''(0)\rangle.$$

第二项是曲线的弯曲 $\boldsymbol{x}''(0)$ 贡献的，它是约束带来的，只看目标 Hessian 看不到这一项。

对恒等式 $h(\boldsymbol{x}(t))=0$ 同样求两次导数，得到

$$\boldsymbol{d}^\top \nabla^2 h(\boldsymbol{x}^\star)\boldsymbol{d} + \langle \nabla h(\boldsymbol{x}^\star), \boldsymbol{x}''(0)\rangle = 0.$$

再由驻定条件 $\nabla f = -\nu \nabla h$，弯曲项可以用约束的 Hessian 表示：

$$\langle \nabla f(\boldsymbol{x}^\star), \boldsymbol{x}''(0)\rangle = -\nu \langle \nabla h(\boldsymbol{x}^\star), \boldsymbol{x}''(0)\rangle = \nu\, \boldsymbol{d}^\top \nabla^2 h(\boldsymbol{x}^\star)\boldsymbol{d}.$$

两式合起来，沿曲线的二阶导数恰好是

$$\boldsymbol{d}^\top \big(\nabla^2 f(\boldsymbol{x}^\star) + \nu \nabla^2 h(\boldsymbol{x}^\star)\big)\boldsymbol{d},$$

括号里是 Lagrange 函数对 $\boldsymbol{x}$ 的 Hessian。乘子把约束的弯曲折算成了目标的曲率。在例子中 $\nabla^2 h = 2\boldsymbol{I}$，$\boldsymbol{d}=(0,1)$，代入 $(1,0)$ 得 $1+2\cdot\frac{1}{2}=2$，代入 $(-1,0)$ 得 $1+2\cdot(-\frac{3}{2})=-2$，与 ϕ'' 完全一致。

一般地，把 Lagrange 函数对 $\boldsymbol{x}$ 的 Hessian 记为

$$\nabla^2_{\boldsymbol{x}\boldsymbol{x}} \mathcal{L}(\boldsymbol{x},\boldsymbol{\lambda},\boldsymbol{\nu}) = \nabla^2 f(\boldsymbol{x}) + \sum_{i=1}^{m} \lambda_i \nabla^2 g_i(\boldsymbol{x}) + \sum_{j=1}^{p} \nu_j \nabla^2 h_j(\boldsymbol{x}). \tag{17.30}$$

定理 17.20 二阶必要条件 设 f、g_i、h_j 在局部最小点 $\boldsymbol{x}^\star$ 附近二阶连续可微，$\boldsymbol{x}^\star$ 满足 LICQ，$(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 是它唯一的 KKT 乘子。则

$$\boldsymbol{d}^{\top} \nabla^2_{\boldsymbol{x}\boldsymbol{x}} \mathcal{L}(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) \boldsymbol{d} \geq 0 \quad \text{对所有 } \boldsymbol{d} \in \boldsymbol{K}(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star). \tag{17.31}$$

证明 取 $\boldsymbol{d} \in \boldsymbol{K}$，令

$$W = \{ i \in A(\boldsymbol{x}^\star) : \langle \nabla g_i(\boldsymbol{x}^\star), \boldsymbol{d} \rangle = 0 \}.$$

由临界锥的定义，$\lambda_i^\star > 0$ 的下标都在 W 中。LICQ 保证引理 17.9适用，得到二阶连续可微的可行曲线 $\boldsymbol{x}(t)$，$0 \leq t < \delta$，它沿 $\boldsymbol{d}$ 出发，并使 h_j 与 g_i（$i \in W$）恒为零。

令 $\phi(t)$ 是乘子固定为 $(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 时 Lagrange 函数沿曲线的值。曲线上等式约束为零，$i \in W$ 的约束为零，其余约束的乘子为零，所以对 $0 \leq t < \delta$，

$$\phi(t) = \mathcal{L}(\boldsymbol{x}(t), \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) = f(\boldsymbol{x}(t)).$$

这是使用 Lagrange 函数的好处：在这条曲线上，它和目标完全一样，但它的梯度在 $\boldsymbol{x}^\star$ 处为零。

由驻定条件，

$$\phi'(0) = \langle \nabla_{\boldsymbol{x}} \mathcal{L}(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star), \boldsymbol{d} \rangle = 0.$$

再求一次导数，含 $\boldsymbol{x}''(0)$ 的项同样因 $\nabla_{\boldsymbol{x}} \mathcal{L} = \boldsymbol{0}$ 消失，得到

$$\phi''(0) = \boldsymbol{d}^{\top} \nabla^2_{\boldsymbol{x}\boldsymbol{x}} \mathcal{L}(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) \boldsymbol{d}.$$

$\boldsymbol{x}(t)$ 可行且趋于局部最小点，所以小的 $t > 0$ 时 $\phi(t) \geq \phi(0)$。由 Taylor 公式，$\phi(t) - \phi(0) = \frac{1}{2}\phi''(0) t^2 + o(t^2)$，除以 t^2 并令 $t \downarrow 0$，得到 $\phi''(0) \geq 0$。 ■

定理中的 LICQ 负责把每个临界方向实现成可行曲线。没有约束资格时，临界方向可能只是线性化的产物。最小化 $-x^2$，约束 $x^2 \leq 0$，原点是唯一可行点，取乘子 $\lambda = 0$ 是一组 KKT 乘子，此时 $\nabla^2_{xx} \mathcal{L} = -2$，$\boldsymbol{K} = \mathbb{R}$，式 (17.31)不成立，而原点当然是最小点。

两种错误的简化 条件 (17.31)既不等同于目标 Hessian 半正定，也不等同于在全空间半正定。圆周例已经说明目标 Hessian 可以正定而点不是局部最小点。

反过来，全空间的不定性也不妨碍极小。最小化 $x_1^2 - x_2^2$，约束 $x_2 = 0$，原点处 $\nu = 0$，Lagrange Hessian 是 $\mathrm{diag}(2, -2)$，不定。但临界锥是 $\{\boldsymbol{d} : d_2 = 0\}$，上面的二次型是 $2d_1^2 \geq 0$。原点确实是最小点，负曲率的方向被约束禁止了。

17.1 约束问题
17.2 可行变化
17.3 约束资格
17.4 乘子条件
17.5 二阶条件
17.5.1 临界锥
17.5.2 二阶必要条件
17.5.3 二阶充分条件
17.6 本章小结

17.5.3 二阶充分条件

必要条件是用来排除的，充分条件是用来确认的。把不等号换成严格，就能确认局部最优，并且还能给出增长的速度。值得注意的是，这里不需要约束资格。

定理 17.21 二阶充分条件 设 f、g_i、h_j 在 $\boldsymbol{x}^\star$ 附近二阶连续可微，$(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 是 KKT 点，并且

$$\boldsymbol{d}^{\mathsf{T}} \nabla^2_{\boldsymbol{x}\boldsymbol{x}} \mathcal{L}(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) \boldsymbol{d} > 0 \quad \text{对所有非零 } \boldsymbol{d} \in \boldsymbol{K}(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star). \tag{17.32}$$

则存在 $\sigma > 0$，$r > 0$，使

$$f(\boldsymbol{x}) \geq f(\boldsymbol{x}^\star) + \sigma \|\boldsymbol{x} - \boldsymbol{x}^\star\|_2^2 \quad \text{对所有 } \boldsymbol{x} \in \boldsymbol{C},\ \|\boldsymbol{x} - \boldsymbol{x}^\star\|_2 < r. \tag{17.33}$$

特别地，$\boldsymbol{x}^\star$ 是严格局部最小点。

证明 反设结论不成立。对每个 k 取 $\sigma = 1/k$，存在可行点 $\boldsymbol{x}^{(k)} \neq \boldsymbol{x}^\star$，$\boldsymbol{x}^{(k)} \to \boldsymbol{x}^\star$，使

$$f(\boldsymbol{x}^{(k)}) < f(\boldsymbol{x}^\star) + \frac{1}{k} \|\boldsymbol{x}^{(k)} - \boldsymbol{x}^\star\|_2^2.$$

记 $t_k = \|\boldsymbol{x}^{(k)} - \boldsymbol{x}^\star\|_2$，$\boldsymbol{d}^{(k)} = (\boldsymbol{x}^{(k)} - \boldsymbol{x}^\star)/t_k$。单位向量列有收敛子列，不妨设 $\boldsymbol{d}^{(k)} \to \boldsymbol{d}$，$\|\boldsymbol{d}\|_2 = 1$。按定义 17.1，$\boldsymbol{d}$ 是切向量，由定理 17.7，$\boldsymbol{d} \in \boldsymbol{F}(\boldsymbol{x}^\star)$。

第一步：$\boldsymbol{d}$ 是临界方向。上面的不等式减去 $f(\boldsymbol{x}^\star)$，除以 t_k，令 $k \to \infty$，得到 $\langle \nabla f(\boldsymbol{x}^\star), \boldsymbol{d} \rangle \leq 0$。第 17.5.1节已经证明，$\boldsymbol{d} \in \boldsymbol{F}$ 时这个内积是非负项之和，所以它等于零。由式 (17.29)，$\boldsymbol{d} \in \boldsymbol{K}$。

第二步：比较 *Lagrange* 函数。下面乘子固定为 $(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$，把 Lagrange 函数简记为 $\mathcal{L}(\boldsymbol{x})$。$\boldsymbol{x}^{(k)}$ 可行，$\boldsymbol{\lambda}^\star \geq \boldsymbol{0}$，所以 $\mathcal{L}(\boldsymbol{x}^{(k)}) \leq f(\boldsymbol{x}^{(k)})$。由互补松弛和等式约束，$\mathcal{L}(\boldsymbol{x}^\star) = f(\boldsymbol{x}^\star)$。于是

$$\mathcal{L}(\boldsymbol{x}^{(k)}) - \mathcal{L}(\boldsymbol{x}^\star) \leq f(\boldsymbol{x}^{(k)}) - f(\boldsymbol{x}^\star) < \frac{t_k^2}{k}.$$

第三步：展开。在 $\boldsymbol{x}^\star$ 处 $\nabla_{\boldsymbol{x}}\mathcal{L}=\mathbf{0}$，由二阶 Taylor 公式，

$$\mathcal{L}(\boldsymbol{x}^{(k)})-\mathcal{L}(\boldsymbol{x}^\star)=\frac{t_k^2}{2}(\boldsymbol{d}^{(k)})^{\top}\nabla^2_{\boldsymbol{xx}}\mathcal{L}(\boldsymbol{x}^\star)\boldsymbol{d}^{(k)}+o(t_k^2).$$

代入上式，除以 t_k^2，令 $k\to\infty$，得到

$$\frac{1}{2}\boldsymbol{d}^{\top}\nabla^2_{\boldsymbol{xx}}\mathcal{L}(\boldsymbol{x}^\star)\boldsymbol{d}\le 0.$$

这与式 (17.32)矛盾。 ■

证明从头到尾没有用到切锥等于线性化锥，只用了 $\boldsymbol{T_C}\subseteq\boldsymbol{F}$ 这个总成立的方向，所以不需要约束资格。它也只要求某一组 KKT 乘子满足式 (17.32)。

在圆周的最近点 $(1,0)$，$\boldsymbol{K}=\{(0,s)\}$，$\nabla^2_{\boldsymbol{xx}}\mathcal{L}=2\boldsymbol{I}$，条件成立。这里增长式可以精确写出。圆周上，

$$f(\boldsymbol{x})-\frac{1}{2}=2-2\cos\theta=\|\boldsymbol{x}-(1,0)\|_2^2,$$

所以 $\sigma=1$。

临界锥只有零向量时，条件 (17.32)自动成立，这时一阶条件就足以确认严格局部最小。预算例 $\tau=1/2$ 的角点就是这样。

条件的边界 严格正性不能放松成半正定。图 17.22中三个一元函数在原点的二阶导数都是零，临界锥都是全空间，半正定都成立，可是 x^3 和 $-x^4$ 的原点都不是局部最小点。

严格正性也不是必要的。x^4 的原点是严格局部最小点，二阶导数却是零。所以二阶必要条件和二阶充分条件之间有一条缝，缝里的情形要靠更高阶的信息或问题的特殊结构。

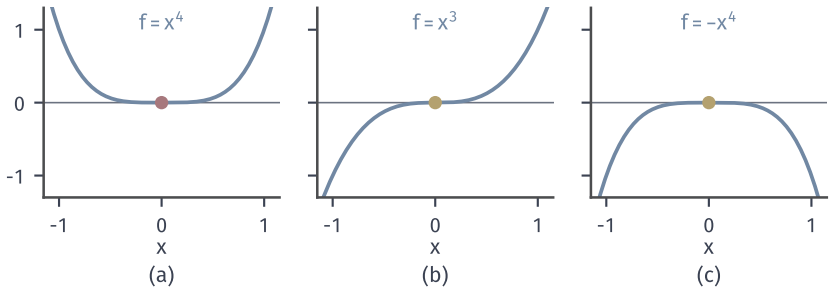


图 17.22 二阶导数为零时，二阶条件无法判决。(a)x^4：原点（红）是严格局部最小点。(b)x^3：原点（黄）不是局部极值点。(c)$-x^4$：原点（黄）是最大点。三者在原点的一、二阶导数都是零。

表 17.5对比这两个条件。

对比项	二阶必要条件	二阶充分条件
出发点	已知局部最小点	已知 KKT 点
约束资格	需要 LICQ	不需要
二次型	在 $\boldsymbol{K}$ 上 ≥ 0	在 $\boldsymbol{K}$ 的非零向量上 > 0
结论	用于排除候选点	严格局部最小，二次增长

表 17.5 二阶必要条件与二阶充分条件的比较。

完整走一遍 最后用一个非凸问题把各项检查串起来：

$$\min_{\boldsymbol{x}\in\mathbb{R}^2} \; -x_1 x_2 \quad \text{s.t.} \quad g(\boldsymbol{x}) = x_1^2 + x_2^2 - 2 \leq 0. \tag{17.34}$$

可行集是紧的圆盘，目标连续，最小点存在。圆盘内部没有活动约束，边界上 $\nabla g = 2\boldsymbol{x} \neq \boldsymbol{0}$，所以 LICQ 在每个可行点成立，每个局部最小点都满足 KKT 条件。

驻定条件是

$$-x_2 + 2\lambda x_1 = 0, \qquad -x_1 + 2\lambda x_2 = 0.$$

由第一式得 $x_2 = 2\lambda x_1$，代入第二式得 $x_1 = 4\lambda^2 x_1$。所以要么 $x_1 = 0$，这时 $x_2 = 0$；要么 $4\lambda^2 = 1$。

若 $x_1 \neq 0$，$\lambda = \pm 1/2$，都不等于零，互补松弛要求约束活动。$\lambda = 1/2$ 时 $x_2 = x_1$，代入 $g = 0$ 得到 $(1,1)$ 与 $(-1,-1)$。$\lambda = -1/2$ 时 $x_2 = -x_1$，得到 $(1,-1)$ 与 $(-1,1)$，但乘子为负，违反式 (17.25)，这两点被排除。负乘子说明从这两点沿半径向内走，目标反而下降，这两点其实是最大点。

留下三个 KKT 点，用二阶条件判决。在原点，$\lambda = 0$，$\boldsymbol{K} = \mathbb{R}^2$，Hessian 和 $\boldsymbol{d} = (1,1)$ 给出

$$\nabla^2_{\boldsymbol{xx}} \mathcal{L} = \begin{bmatrix} 0 & -1 \\ -1 & 0 \end{bmatrix}, \qquad \boldsymbol{d}^{\top} \nabla^2_{\boldsymbol{xx}} \mathcal{L}\, \boldsymbol{d} = -2 < 0.$$

原点不满足二阶必要条件，不是局部最小点。

在 $(1,1)$，$\lambda = 1/2 > 0$，临界锥要求 $\langle \nabla g, \boldsymbol{d} \rangle = 2d_1 + 2d_2 = 0$，即 $\boldsymbol{d} = s(1,-1)$。Lagrange Hessian 是

$$\nabla^2_{\boldsymbol{xx}} \mathcal{L} = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}, \qquad \boldsymbol{d}^{\top} \nabla^2_{\boldsymbol{xx}} \mathcal{L}\, \boldsymbol{d} = 4s^2 > 0 \;\; (s \neq 0).$$

这个矩阵只是半正定，在 $(1,1)$ 方向为零，但 $(1,1)$ 不是临界方向。二阶充分条件成立，$(1,1)$ 是严格局部最小点。$(-1,-1)$ 由对称性相同。

17.1　约束问题
17.2　可行变化
17.3　约束资格
17.4　乘子条件
17.5　二阶条件
17.6　本章小结

全局最小点存在，又一定在 KKT 点中。比较目标值，$f(\pm(1,1)) = -1$，$f(\mathbf{0}) = 0$，所以最优值是 -1，全局最小点是这两点。这一步用的是“存在性、约束资格、枚举全部候选”这一套全局论证，单靠二阶条件得不到。图 17.23把五个候选点标在一起。

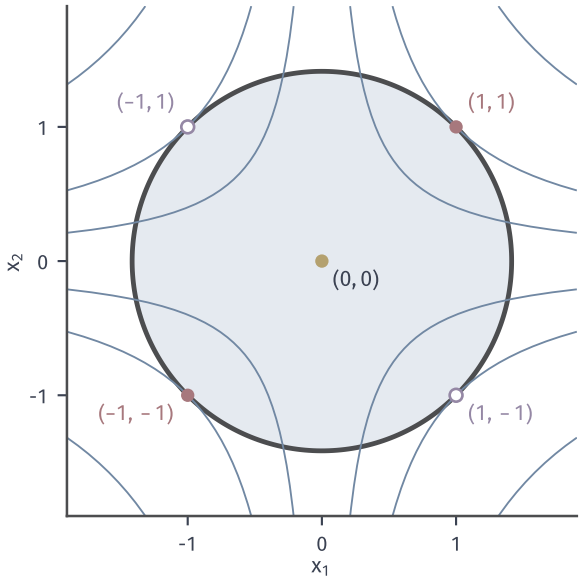


图 17.23　问题 (17.34)的候选点。浅蓝圆盘是可行集，蓝线是 $-x_1x_2$ 的等高线。红点 $\pm(1,1)$ 是全局最小点。黄点 $(0,0)$ 是 KKT 点，但二阶必要条件不成立。紫色空心点 $\pm(1,-1)$ 满足驻定和活动条件，乘子为 $-1/2$，不是 KKT 点。

17.6　本章小结

本章回答的问题是：给定一个候选点，怎样只用它附近的信息判断它是否最优。答案不是一个公式，而是按顺序做的几项检查，每一项给出的结论强弱不同，见图 17.24。

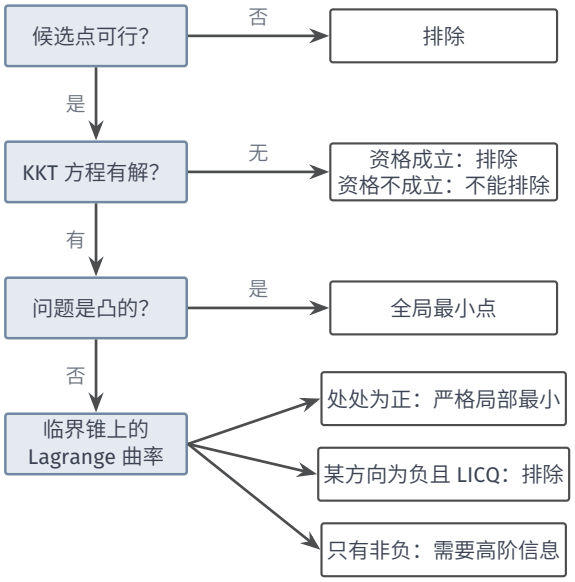


图 17.24 判断候选点的流程。左列依次是可行性、KKT 方程、凸性和临界锥上的曲率四项检查，右列是对应的结论。“资格”指候选点满足的约束资格，如 LICQ 或 MFCQ。

第一项检查是可行性，并找出活动约束。不活动的约束在局部不起作用，所以后面的条件只看活动约束和等式约束。

第二项检查是真实的局部方向。切锥只依赖可行集，它给出最根本的必要条件：局部最小点处，切锥中没有一阶下降方向。线性化锥好算，但可能多出虚假方向。LICQ 和 MFCQ 保证两者相等，这两个条件只涉及约束函数在该点的梯度，与目标的凸性无关，并且会随约束的写法改变。

第三项检查是 KKT 条件。Farkas 引理把“线性化锥中没有下降方向”换成负梯度属于活动梯度的非负锥，由此得到驻定、原始可行、乘子非负和互补松弛四组条件。在 MFCQ 下它们是局部最小点的必要条件，LICQ 进一步保证乘子唯一。没有约束资格时，最小点可以没有乘子。

局部结论和全局结论要分开。目标和不等式约束函数凸、等式约束仿射时，任何 KKT 点都是全局最小点，这不需要约束资格。一般非凸问题中，KKT 点只是候选，全局结论要靠存在性和枚举等其他依据。

第四项检查是曲率。只有一阶变化为零的方向才需要二阶判断，这些方向组成临界锥，零乘子的活动约束在其中保留单侧限制。约束的弯曲通过乘子进入 Lagrange 函数的 Hessian，所以检查的是 Lagrange Hessian 在临界锥上的二次型，不是目标 Hessian，也不是全空间的正定性。LICQ 下二次型非负是必要条件；在某组 KKT 乘子下对非零临界方向严格为正是充分条件，并且给出局部二次增长，这一方向不需要约束资格。两者之间的退化情形，二阶信息判断不了。

这些条件都在已知候选点时做判断，没有回答候选点从哪里来。下一章用乘子构造整个问题的下界，把这里局部的条件变成可以检验的全局证书。可行迭代、乘子更新和局部子问题怎样产生满足这些条件的点，由第 21章至第 24章研究。

18.1 下界的构造
18.1.1 对偶函数
18.1.2 对偶问题
18.2 弱对偶
18.3 凸共轭
18.4 强对偶
18.5 最优性证书
18.6 本章小结

第 18 章

对偶问题

求解约束问题时，算法交出一个可行点，目标值是 0.40625。这个数够好吗？可行点本身只说明最优值不超过 0.40625，至于离最优值还差多少，它什么也没有说。第 17章的 KKT 条件能判断一个候选是否满足最优点应有的关系，却不能给一个非最优的候选打分。要回答“还差多少”，必须另有一个不超过最优值的数，也就是下界。

第 2章已经见过这样的下界：把约束乘上权重加起来，得到一份能当场核对的证据。本章把这个办法推广到一般的约束问题。目标和约束不再是线性的，加权之后也就不能靠比较系数得出下界，而要对原变量取一次下确界。

第 18.1节构造下界，第 18.2节说明它为什么总是成立，以及怎样用它给可行点估计误差。下确界的计算反复出现“函数加线性项”的结构，第 18.3节把这个结构提取出来，得到计算对偶问题的工具。

最好的下界未必等于最优值。第 18.4节研究两者何时相等，并把“相等”“原始最优点存在”“最优乘子存在”这三件事分开。第 18.5节把上下界、KKT 条件和鞍点放到同一对原始—对偶候选上比较，说明它们各自检验了什么。

18.1 下界的构造

对一般的约束问题，怎样写出一个不依赖未知最优点的下界？全章讨论的问题是

$$\begin{aligned} \min_{\boldsymbol{x}\in\boldsymbol{D}} \quad & f(\boldsymbol{x}) \\ \text{s.t.} \quad & g_i(\boldsymbol{x}) \le 0, \quad i = 1, \dots, m, \\ & h_j(\boldsymbol{x}) = 0, \quad j = 1, \dots, p. \end{aligned} \tag{18.1}$$

这里 $\boldsymbol{D} \subseteq \mathbb{R}^n$ 是规定的定义域，f, g_i, h_j 在其上都取有限值。没有特别说明时 $\boldsymbol{D} = \mathbb{R}^n$；有些问题只在一部分点上有定义，或者我们有意把一些简单约束（例如 $\boldsymbol{x} \ge \boldsymbol{0}$）留在 $\boldsymbol{D}$ 里。

式 (18.1)称为原始问题，它的最优值记为 $f^\star$，是可行点上目标值的下确界。没有可行点时规定 $f^\star = +\infty$。我们不假设最小点存在，也不假设问题是凸的，这两点在后面都很重要。

第 17章为这个问题定义了 Lagrange 函数，给每条不等式配乘子 λ_i，每条等式配乘子 ν_j：

$$\mathcal{L}(\boldsymbol{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}) = f(\boldsymbol{x}) + \sum_{i=1}^{m} \lambda_i g_i(\boldsymbol{x}) + \sum_{j=1}^{p} \nu_j h_j(\boldsymbol{x}). \tag{18.2}$$

那里用它写出候选点上的驻定条件，这里换一个用法：把它当成原目标的一个替身。

用线性价格代替无穷的墙 约束可以看成目标里的一堵墙。令 $\iota_{\le 0}(u)$ 在 $u \le 0$ 时为 0，在 $u > 0$ 时为 $+\infty$，则不等式约束等价于在目标上加 $\iota_{\le 0}(g_i(\boldsymbol{x}))$。这个函数太硬，无法与目标一起处理。

换成一条斜率 $\lambda \ge 0$ 的直线 λu。图 18.1(a) 显示，不论 λ 取多少，直线都在墙的下方：$u \le 0$ 时 $\lambda u \le 0$，$u > 0$ 时墙是 $+\infty$。用直线替换墙，得到的函数不会超过原来带墙的目标。

这正是价格的想法。约束超支一单位就付 λ 的罚款，有结余就按同样的价格退款，违反约束不再被禁止，只是要付钱。等式约束的乘子 ν_j 没有符号限制，因为 $h_j = 0$ 时无论乘什么数，这一项都为零。这个类比只帮助记住不等式的方向，并不表示真的存在这样的市场。

下面用一个能画出来的例子走一遍，全章称它为一元例：

$$\min_{x \in \mathbb{R}} \ \frac{1}{2}(x-2)^2 \quad \text{s.t.} \quad x - 1 \le 0. \tag{18.3}$$

无约束最小点 $x = 2$ 不可行，所以解在边界 $x^\star = 1$ 上，最优值 $f^\star = 1/2$。

取 $\lambda = 1/2$，Lagrange 函数是

$$\mathcal{L}(x, \tfrac{1}{2}) = \frac{1}{2}(x-2)^2 + \frac{1}{2}(x-1).$$

在可行点 $x \le 1$ 上，第二项不大于零，所以 $\mathcal{L}(x, \frac{1}{2}) \le f(x)$。图 18.1(b) 中，紫色曲线在阴影区都位于蓝色曲线下方，并且全部经过 $(1, \frac{1}{2})$，因为那里约束的值恰好为零。

对 x 求最小，驻点满足 $x - 2 + \frac{1}{2} = 0$，即 $x = \frac{3}{2}$，最小值是

$$\mathcal{L}(\tfrac{3}{2}, \tfrac{1}{2}) = \frac{1}{8} + \frac{1}{4} = \frac{3}{8}.$$

18.1 下界的构造
18.1.1 对偶函数
18.1.2 对偶问题
18.2 弱对偶
18.3 凸共轭
18.4 强对偶
18.5 最优性证书
18.6 本章小结

这个最小点并不可行，这没有关系。它是 $\mathcal{L}$ 在整条数轴上的最小值，当然不超过 $\mathcal{L}$ 在可行点上的值，而后者又不超过 f。于是我们没有用到 $x^\star$，就知道 $f^\star \geq 3/8$。

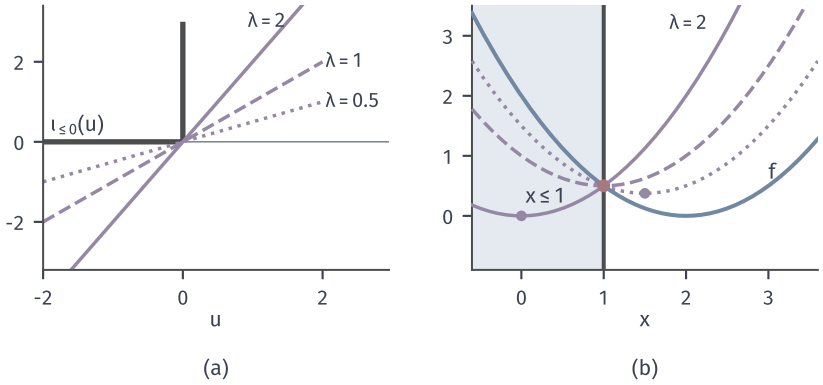


图 18.1　用线性价格代替硬约束。(a) 深灰粗线是硬约束 $\iota_{\leq 0}(u)$，紫线是 λu，点线、虚线、实线分别对应 $\lambda = 0.5, 1, 2$，都在粗线下方。(b) 一元例 (18.3)：蓝线是目标 f，浅蓝区域是可行集 $x \leq 1$，紫线是 $\mathcal{L}(\cdot, \lambda)$，线型含义同 (a)；紫点是各自的最小点，红点是原始最优点。

这段推理里最容易出错的一步，是必须对 $\boldsymbol{D}$ 上的全部点取下确界。只求一个驻点是不够的。在 $\boldsymbol{D} = [-3, 3]$ 上考虑 $f(x) = x^3 - 3x$，约束 $x - 2 \leq 0$，取 $\lambda = 0$，则 $\mathcal{L} = f$。驻点 $x = 1$ 是局部极小点，值为 -2，但可行点 $x = -3$ 的目标值是 -18。局部极小值 -2 不是下界。

18.1.1 对偶函数

把上面的做法写成定义。固定乘子以后，对原变量取下确界，得到的数只依赖乘子。

定义 18.1　对偶函数　问题 (18.1)的对偶函数（dual function）是

$$q(\boldsymbol{\lambda}, \boldsymbol{\nu}) = \inf_{\boldsymbol{x} \in \boldsymbol{D}} \mathcal{L}(\boldsymbol{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}), \tag{18.4}$$

允许取 $-\infty$。使 q 取有限值的乘子组成它的有效定义域 $\operatorname{dom} q$。满足 $\boldsymbol{\lambda} \geq \boldsymbol{0}$ 且 $(\boldsymbol{\lambda}, \boldsymbol{\nu}) \in \operatorname{dom} q$ 的乘子称为对偶可行的乘子。

注意下确界有三种可能，定义中用 inf 而不是 min，正是为了把它们都包括进去。第一种是最小点存在，例如一元例。第二种是下确界为 $-\infty$：在 $\mathbb{R}$ 上最小化 $-x^2$，约束写成 $x - 1 \leq 0$ 和 $-x - 1 \leq 0$，则 $\mathcal{L}$ 对任何乘子都是开口向下的二次函数，$q \equiv -\infty$。这时对偶函数没有提供信息。

第三种是下确界有限但取不到。考虑 $\min e^{-x}$，约束 $-x \le 0$。取 $\lambda = 0$，则

$$q(0) = \inf_{x \in \mathbb{R}} e^{-x} = 0,$$

这个值没有任何 x 能达到。而 $\lambda > 0$ 时，$e^{-x} - \lambda x$ 在 $x \to +\infty$ 时趋于 $-\infty$，所以 $q(\lambda) = -\infty$。

现在用第 17章的等式二次例计算一个完整的对偶函数，全章称它为二次例：

$$\min_{\boldsymbol{x} \in \mathbb{R}^2} \ \frac{1}{2}(x_1^2 + 4x_2^2) \quad \text{s.t.} \quad x_1 + x_2 - 1 = 0. \tag{18.5}$$

那里已经由切向导数为零求出最小点 $(4/5, 1/5)$，最优值是

$$f^\star = \frac{1}{2}\Big(\frac{16}{25} + \frac{4}{25}\Big) = \frac{2}{5}.$$

下面不用这个答案，只用对偶函数。Lagrange 函数是

$$\mathcal{L}(\boldsymbol{x}, \nu) = \frac{1}{2}(x_1^2 + 4x_2^2) + \nu(x_1 + x_2 - 1).$$

固定 ν，它是 $\boldsymbol{x}$ 的严格凸二次函数，令梯度为零就得到唯一的全局最小点：

$$x_1 + \nu = 0, \qquad 4x_2 + \nu = 0.$$

因此

$$x_1(\nu) = -\nu, \qquad x_2(\nu) = -\frac{\nu}{4}.$$

代回 $\mathcal{L}$，两个平方项和约束项分别是

$$\frac{1}{2}\Big(\nu^2 + \frac{\nu^2}{4}\Big) = \frac{5}{8}\nu^2, \qquad \nu\Big(-\nu - \frac{\nu}{4} - 1\Big) = -\frac{5}{4}\nu^2 - \nu.$$

相加得到关于 ν 的一元函数

$$q(\nu) = -\frac{5}{8}\nu^2 - \nu. \tag{18.6}$$

这是一条开口向下的抛物线。令导数 $-\frac{5}{4}\nu - 1 = 0$，得到

$$\nu^\star = -\frac{4}{5}, \qquad q(\nu^\star) = -\frac{2}{5} + \frac{4}{5} = \frac{2}{5}.$$

最好的下界恰好等于 $f^\star = 2/5$，同时 $\boldsymbol{x}(\nu^\star) = (4/5, 1/5)$ 也正是原问题的解。

图 18.2(a) 显示了这个过程。ν 的作用是在目标上加一个倾斜的线性项，把碗底从原点沿紫色虚线推走。$\nu = 0$ 时碗底在原点，不满足约束；$\nu = -4/5$

时碗底恰好落到约束直线上。图 18.2(b) 是这个过程中碗底的高度随 ν 的变化，也就是 $q(\nu)$。

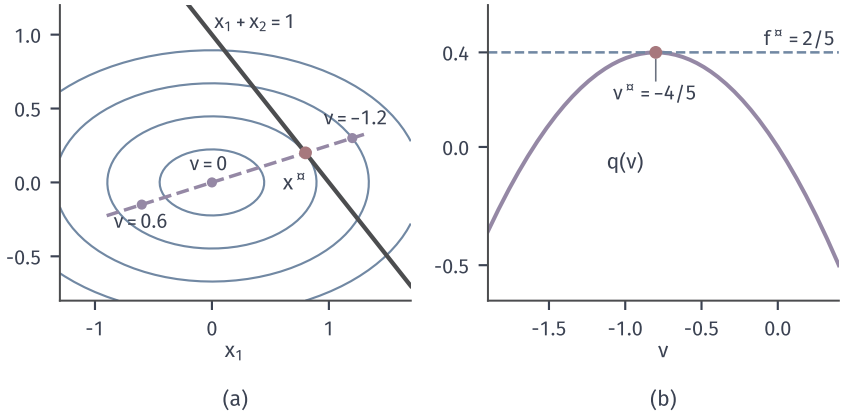


图 18.2 二次例 (18.5)的对偶函数。(a) 蓝线是目标的等高线，深灰粗线是约束 $x_1 + x_2 = 1$，紫色虚线是内层最小点 $\boldsymbol{x}(\nu) = (-\nu, -\nu/4)$ 的轨迹，红点是 $\boldsymbol{x}^\star$。(b) 紫线是 $q(\nu)$，它处处不超过蓝色虚线 $f^\star$，在 $\nu^\star = -4/5$ 处相等。

不等式约束的对偶函数要多处理一件事：内层的 $\boldsymbol{D}$ 可以有边界，最小点会在边界上换挡。第 17章的预算例取 $\tau = 2$，就是这种情形，全章称它为预算例：

$$\min_{\boldsymbol{x}\geq\boldsymbol{0}} \ \frac{1}{2}\big[(x_1-2)^2 + (x_2-1)^2\big] \quad \text{s.t.} \quad x_1 + x_2 - 2 \leq 0. \tag{18.7}$$

把 $\boldsymbol{x} \geq \boldsymbol{0}$ 留在 $\boldsymbol{D} = \mathbb{R}^2_+$ 中，只给预算约束配乘子 $\lambda \geq 0$。

此时内层问题按坐标分开：

$$\min_{x_1\geq 0}\Big[\frac{1}{2}(x_1-2)^2 + \lambda x_1\Big] + \min_{x_2\geq 0}\Big[\frac{1}{2}(x_2-1)^2 + \lambda x_2\Big] - 2\lambda.$$

每一项是开口向上的一元二次函数在半轴上的最小化，最小点是无约束最小点截断到非负：

$$x_1(\lambda) = \max\{2-\lambda, 0\}, \qquad x_2(\lambda) = \max\{1-\lambda, 0\}.$$

λ 越过 1 时第二个坐标碰到边界，越过 2 时第一个坐标也碰到边界。分三段代入，得到

$$q(\lambda) = \begin{cases} \lambda - \lambda^2, & 0 \leq \lambda \leq 1, \\ \dfrac{1}{2} - \dfrac{1}{2}\lambda^2, & 1 \leq \lambda \leq 2, \\ \dfrac{5}{2} - 2\lambda, & \lambda \geq 2. \end{cases} \tag{18.8}$$

18.1　下界的构造
18.1.1　对偶函数
18.1.2　对偶问题
18.2　弱对偶
18.3　凸共轭
18.4　强对偶
18.5　最优性证书
18.6　本章小结

三段在分界点连续：$\lambda = 1$ 时都是 0，$\lambda = 2$ 时都是 $-3/2$。第一段的最大点是 $\lambda^\star = 1/2$，最好的下界是 $q(1/2) = 1/4$。

这个例子的解是 $\boldsymbol{x}^\star = (3/2, 1/2)$，目标值 $\frac{1}{2}(\frac{1}{4} + \frac{1}{4}) = \frac{1}{4}$，下界再次与最优值相等。图 18.3中，内层最小点随 λ 增大沿折线向原点移动，价格越高，用得越少；q 相应地分成三段。

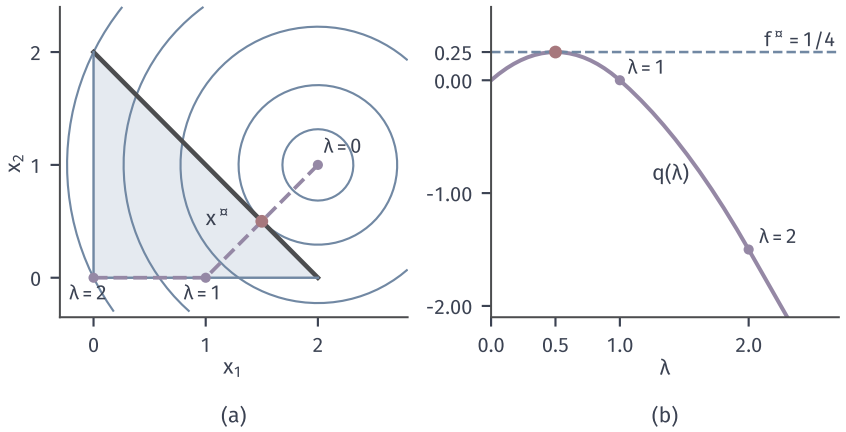


图 18.3　预算例 (18.7)的对偶函数。(a) 浅蓝区域是可行集，深灰粗线是预算约束，蓝线是目标等高线，紫色虚线是内层最小点 $\boldsymbol{x}(\lambda)$ 随 λ 从 0 增大的轨迹，紫点是 $\lambda = 0, 1, 2$ 时的位置，红点是 $\boldsymbol{x}^\star$。(b) 紫线是分段的 $q(\lambda)$，紫点是分界点，红点是最大点 $(1/2, 1/4)$。

18.1.2　对偶问题

每组合法的乘子给出一个下界，下界越大提供的信息越多。很自然地，我们想要最大的那个，于是得到一个新的优化问题。

定义 18.2　对偶问题　问题 (18.1)的对偶问题是在合法乘子上最大化对偶函数，

$$d^\star = \sup_{\boldsymbol{\lambda} \geq \mathbf{0},\, \boldsymbol{\nu}} q(\boldsymbol{\lambda}, \boldsymbol{\nu}), \tag{18.9}$$

其最优值 $d^\star$ 可以取 $\pm\infty$；对偶可行的乘子不存在时 $d^\star = -\infty$。达到这个上确界的乘子称为对偶最优乘子。

这里的约束只有 $\boldsymbol{\lambda} \geq \mathbf{0}$，比原问题简单。更值得注意的是目标函数的形状。图 18.3(b) 和图 18.2(b) 中的 q 都是凹的，这不是巧合。

要看出原因，把 $\mathcal{L}$ 反过来读：固定 $\boldsymbol{x}$，它关于乘子是仿射函数，斜率是约束值 $g_i(\boldsymbol{x})$ 与 $h_j(\boldsymbol{x})$，截距是 $f(\boldsymbol{x})$。q 是这一族直线的下包络。图 18.4中一元例的每条直线对应一个 x，它们的下包络（紫线）向下弯曲。

定理 18.3 对偶函数是凹的 对问题 (18.1)，无论 f, g_i, h_j 和 $\boldsymbol{D}$ 是否凸，q 都是凹函数，$\operatorname{dom} q$ 是凸集。

证明 记 $\boldsymbol{a} = (\boldsymbol{\lambda}, \boldsymbol{\nu})$。任取 $\boldsymbol{a}_1, \boldsymbol{a}_2$ 和 $\theta \in [0,1]$，令 $\boldsymbol{a} = \theta\boldsymbol{a}_1 + (1-\theta)\boldsymbol{a}_2$。$\mathcal{L}$ 对乘子是仿射的，所以对每个 $\boldsymbol{x} \in \boldsymbol{D}$，

$$\mathcal{L}(\boldsymbol{x}, \boldsymbol{a}) = \theta\mathcal{L}(\boldsymbol{x}, \boldsymbol{a}_1) + (1-\theta)\mathcal{L}(\boldsymbol{x}, \boldsymbol{a}_2).$$

由下确界的定义，右端不小于 $\theta q(\boldsymbol{a}_1) + (1-\theta) q(\boldsymbol{a}_2)$。对 $\boldsymbol{x} \in \boldsymbol{D}$ 取下确界，得到

$$q(\boldsymbol{a}) \geq \theta q(\boldsymbol{a}_1) + (1-\theta) q(\boldsymbol{a}_2).$$

若 $\boldsymbol{a}_1, \boldsymbol{a}_2 \in \operatorname{dom} q$，右端有限，于是 $\boldsymbol{a} \in \operatorname{dom} q$。 ■

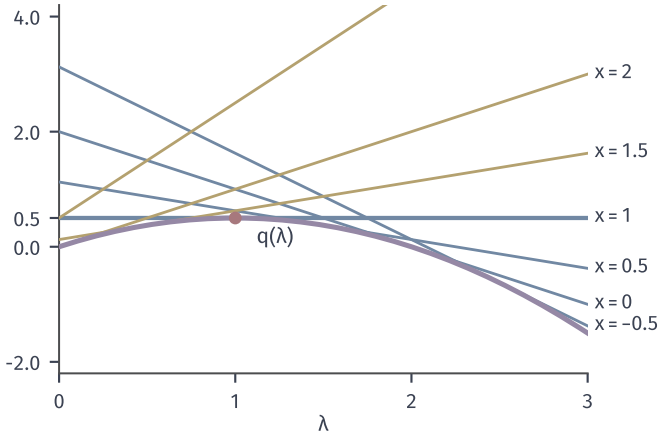


图 18.4 一元例中，每个固定的 x 给出一条直线 $\lambda \mapsto \mathcal{L}(x, \lambda)$，蓝线对应可行的 x，黄线对应不可行的 x（最陡的一条是 $x = 3$），紫线是下包络 $q(\lambda) = \lambda - \lambda^2/2$。可行点的直线斜率不为正，所以在 $\lambda \geq 0$ 上不超过其截距 $f(x)$；水平粗线是 $x = 1$，高度为 $f^\star = 1/2$，在红点处与 q 相切。

定理 18.3说的是一个凸优化问题总摆在手边，无论原问题多么复杂，最大化一个凹函数原则上没有多余的局部最优。但这并不意味着对偶问题容易求解。计算 q 的一个值就要做一次内层的全局最小化，而内层目标 $\mathcal{L}(\cdot, \boldsymbol{\lambda}, \boldsymbol{\nu})$ 可以和原目标一样非凸。前面 $f(x) = x^3 - 3x$ 的例子说明，局部解在这里给不出下界。凹性属于外层，难度可能全部留在内层。

线性规划是内层可以完全算出的特例。把第 2章的标准型 $\min \boldsymbol{c}^\top \boldsymbol{x}, \boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$，$\boldsymbol{x} \geq \boldsymbol{0}$ 放进这个框架，取 $\boldsymbol{D} = \mathbb{R}^n$。给不等式 $-\boldsymbol{x} \leq \boldsymbol{0}$ 配乘子 $\boldsymbol{s} \geq \boldsymbol{0}$，给等式配乘子 $-\boldsymbol{y}$，则

$$\mathcal{L} = \boldsymbol{c}^\top \boldsymbol{x} - \boldsymbol{y}^\top(\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}) - \boldsymbol{s}^\top \boldsymbol{x} = \boldsymbol{b}^\top \boldsymbol{y} + (\boldsymbol{c} - \boldsymbol{A}^\top \boldsymbol{y} - \boldsymbol{s})^\top \boldsymbol{x}.$$

18.1 下界的构造
18.2 弱对偶
18.2.1 可行候选的误差证书
18.2.2 内层近似的方向
18.3 凸共轭
18.4 强对偶
18.5 最优性证书
18.6 本章小结

这是 $\boldsymbol{x}$ 的线性函数，只有斜率为零时下确界才有限：

$$q(\boldsymbol{s},\boldsymbol{y})=\begin{cases}\boldsymbol{b}^{\top}\boldsymbol{y}, & \boldsymbol{A}^{\top}\boldsymbol{y}+\boldsymbol{s}=\boldsymbol{c},\\ -\infty, & \text{其他情形.}\end{cases}$$

第 2章对偶问题的等式约束 $\boldsymbol{A}^{\top}\boldsymbol{y}+\boldsymbol{s}=\boldsymbol{c}$，在这里的含义是 $\operatorname{dom} q$ 的条件。把 $q=-\infty$ 的乘子排除后，再最大化 $\boldsymbol{b}^{\top}\boldsymbol{y}$，就回到了那里的对偶问题。

18.2 弱对偶

上一节在例子里反复看到“下界不超过最优值”。这个结论在什么范围内成立，它又能为手里的候选点提供什么？

定理 18.4 弱对偶 对问题 (18.1)的任一可行点 $\boldsymbol{x}$ 和任一组 $\boldsymbol{\lambda}\geq\boldsymbol{0}$、$\boldsymbol{\nu}$，有

$$q(\boldsymbol{\lambda},\boldsymbol{\nu})\leq f(\boldsymbol{x}). \tag{18.10}$$

因而

$$d^{\star}\leq f^{\star}. \tag{18.11}$$

证明 由可行性和 $\boldsymbol{\lambda}\geq\boldsymbol{0}$，有 $\lambda_i g_i(\boldsymbol{x})\leq 0$ 和 $\nu_j h_j(\boldsymbol{x})=0$，所以这些项都不使 $f(\boldsymbol{x})$ 增大。又因为 $\boldsymbol{x}\in\boldsymbol{D}$，由下确界的定义，

$$q(\boldsymbol{\lambda},\boldsymbol{\nu})\leq\mathcal{L}(\boldsymbol{x},\boldsymbol{\lambda},\boldsymbol{\nu})\leq f(\boldsymbol{x}).$$

左边不含 $\boldsymbol{x}$，对可行点取下确界，再对合法乘子取上确界，就得到式 (18.11)。没有可行点时 $f^{\star}=+\infty$，式 (18.11)自然成立。 ■

证明只用了两件事：下确界的定义，以及符号。它不需要凸性，不需要可微性，也不需要任何约束资格。正因为条件这样少，弱对偶可以用于任何问题，这是它最大的价值。

弱对偶这个名字在第 2章已经出现过，那里说的是线性规划的特例。两个差要分清。一个是某一对候选的差 $f(\boldsymbol{x})-q(\boldsymbol{\lambda},\boldsymbol{\nu})$，下面称为候选间隙，算法每一步都能算出。另一个是两个最优值的差 $f^{\star}-d^{\star}$，这是问题本身的性质，称为**对偶间隙**。候选间隙总不小于对偶间隙。

在目标—约束平面上看弱对偶 把每个 x 映成平面上的一点 $(u,t)=(g(x),f(x))$，横坐标是约束值，纵坐标是目标值，这些点组成集合 $\boldsymbol{G}$。对一元例，$u=x-1$，$t=\frac{1}{2}(u-1)^2$，$\boldsymbol{G}$ 是一条抛物线，如图 18.5所示。可行点对应 $u\leq 0$，原始问题就是在竖线左侧找 $\boldsymbol{G}$ 的最低点。

18.1 下界的构造
18.2 弱对偶
18.2.1 可行候选的误差证书
18.2.2 内层近似的方向
18.3 凸共轭
18.4 强对偶
18.5 最优性证书
18.6 本章小结

$\mathcal{L} = t + \lambda u$ 在斜率为 $-\lambda$ 的直线上为常数。$q(\lambda)$ 就是把这样的直线从下方推到刚好碰到 $\boldsymbol{G}$，这条直线与竖轴 $u = 0$ 的交点高度。

所以弱对偶的几何含义是：直线在 $\boldsymbol{G}$ 下方，$\lambda \geq 0$ 时它在 $u \leq 0$ 一侧向左不下降，因此 $\boldsymbol{G}$ 中 $u \leq 0$ 的部分都在交点上方。对偶问题就是转动直线，使交点尽量高。λ 取负数时直线向左下降，交点就可能高过可行部分的最低点，后面会看到这个现象。

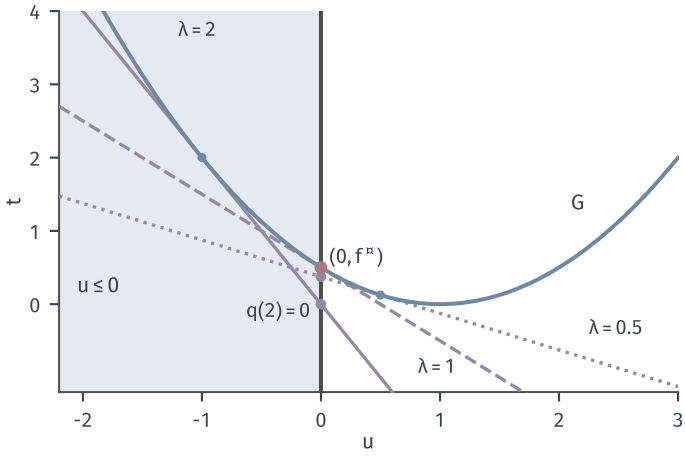


图 18.5 一元例在 $(u, t) = (g(x), f(x))$ 平面上的像。蓝线是 $\boldsymbol{G}$，浅蓝区域是可行的半平面 $u \leq 0$，深灰粗线是 $u = 0$。紫线是斜率 $-\lambda$ 的支撑直线（$\lambda = 0.5, 1, 2$，分别为点线、虚线、实线），它们在 $\boldsymbol{G}$ 下方，与 $u = 0$ 的交点（紫点）高度就是 $q(\lambda)$，分别为 0.375、0.5、0。红点 $(0, f^\star)$ 是 $\lambda = 1$ 时的切点。

18.2.1 可行候选的误差证书

现在回答本章开头的问题。手里有一个可行点 $\hat{\boldsymbol{x}}$ 和一组合法乘子 $(\boldsymbol{\lambda}, \boldsymbol{\nu})$，由弱对偶，最优值被夹在两个可计算的数之间：

$$q(\boldsymbol{\lambda}, \boldsymbol{\nu}) \leq f^\star \leq f(\hat{\boldsymbol{x}}). \tag{18.12}$$

两边同时减去，得到次优性的一个可以计算的上界：

$$0 \leq f(\hat{\boldsymbol{x}}) - f^\star \leq f(\hat{\boldsymbol{x}}) - q(\boldsymbol{\lambda}, \boldsymbol{\nu}). \tag{18.13}$$

右端不含 $f^\star$，这一对候选本身就是一份误差证书。第 1章讨论过目标差难以计算的困难，这里给出了一种解决办法。

用二次例算一组不是最优的候选。取可行点和乘子

$$\hat{\boldsymbol{x}} = \left(\frac{3}{4}, \frac{1}{4}\right), \qquad \nu = -\frac{3}{4}.$$

原始目标值由定义计算，对偶目标值由式 (18.6)计算：

$$f(\hat{\boldsymbol{x}}) = \frac{1}{2}\Big(\frac{9}{16} + \frac{4}{16}\Big) = \frac{13}{32}, \qquad q\Big(-\frac{3}{4}\Big) = -\frac{45}{128} + \frac{3}{4} = \frac{51}{128}.$$

候选间隙是

$$\frac{13}{32} - \frac{51}{128} = \frac{52-51}{128} = \frac{1}{128} \approx 0.0078.$$

所以不用知道答案，我们就确认 $\hat{\boldsymbol{x}}$ 的目标差不超过 0.0078。

因为这个例子知道答案，可以核对证书有多紧。真实目标差和乘子一侧的差分别是

$$\frac{13}{32} - \frac{2}{5} = \frac{1}{160}, \qquad \frac{2}{5} - \frac{51}{128} = \frac{1}{640}.$$

两者之和是

$$\frac{1}{160} + \frac{1}{640} = \frac{5}{640} = \frac{1}{128},$$

正是候选间隙。候选间隙同时度量了原始和对偶两侧的误差，图 18.6把这几个数放在同一条数轴上。

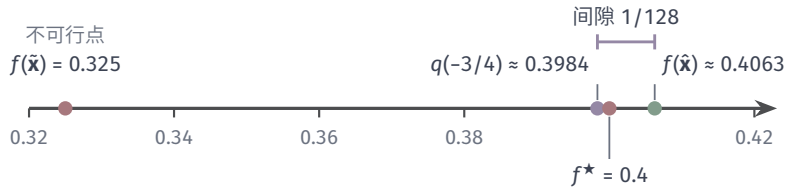


图 18.6 二次例的误差证书。紫点是下界 $q(-3/4)$，绿点是可行点 $\hat{\boldsymbol{x}}$ 的目标值，红点 $f^\star$ 夹在两者之间，紫色括线是候选间隙。左边的红点是不可行点 $\tilde{\boldsymbol{x}} = (0.7, 0.2)$ 的目标值，它比 $f^\star$ 低，不能用来估计误差。

式 (18.13)有三个前提，每一个都要单独检验，下面逐一看缺了会怎样。

第一个是原始可行性。点 $\tilde{\boldsymbol{x}} = (0.7, 0.2)$ 不满足约束，因为 $0.7 + 0.2 \neq 1$。它的目标值只有

$$f(\tilde{\boldsymbol{x}}) = \frac{1}{2}(0.49 + 0.16) = 0.325,$$

比最优值低，与下界的差是 $0.325 - 0.3984 \approx -0.073$，是负数。负的“间隙”在这里暴露了不可行，但一般不能指望这样：不可行点也可能给出正的小间隙。所以约束残差要另外计算，不能从间隙看出来。

第二个是乘子的合法性。考虑 $\min x^2$，约束 $x - 1 \le 0$，最优值 $f^\star = 0$。内层最小点是 $x = -\lambda/2$，代回得到

$$q(\lambda) = -\frac{\lambda^2}{4} - \lambda.$$

18.1 下界的构造
18.2 弱对偶
18.2.1 可行候选的误差证书
18.2.2 内层近似的方向
18.3 凸共轭
18.4 强对偶
18.5 最优性证书
18.6 本章小结

这个公式对负的 λ 照样能算，例如 $\lambda=-2$ 时给出 $q=1$，比真实最优值 0 还大。

错在哪里？$\lambda=-2$ 时，可行点 $x=0$ 上的 $\mathcal{L}=0-2(0-1)=2$，比 $f(0)=0$ 大，证明中 $\mathcal{L}\le f$ 这一步失效。图 18.7中红色虚线高过了 $f^\star$，这段就是不合法的乘子。

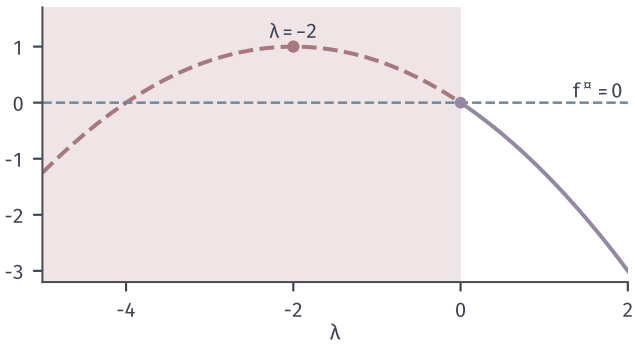


图 18.7　乘子合法性的作用。问题是 $\min x^2$，约束 $x-1\le 0$。紫线是 $\lambda\ge 0$ 时的 $q(\lambda)$，始终不超过蓝色虚线 $f^\star=0$；红色虚线和浅红区域对应 $\lambda<0$，同一个公式在这里可以超过 $f^\star$，例如 $\lambda=-2$ 时为 1，它不是下界。

第三个前提是下界本身算得可信，也就是内层下确界确实是下确界。这一点在实际计算中最容易被忽略，单独放在下一小节讨论。

18.2.2 内层近似的方向

计算 q 需要解一个最小化问题。多数情况下内层得不到解析解，只能迭代到某个近似点 $\tilde{\boldsymbol{x}}$。这样算出的 $\mathcal{L}(\tilde{\boldsymbol{x}},\boldsymbol{\lambda},\boldsymbol{\nu})$ 可不可以当作下界使用？

答案是不可以，而且误差的方向恰好不对。由下确界的定义，

$$\mathcal{L}(\tilde{\boldsymbol{x}},\boldsymbol{\lambda},\boldsymbol{\nu})\ge q(\boldsymbol{\lambda},\boldsymbol{\nu}),$$

近似值落在真正下界的上方。普通的数值误差只让答案不够精确，这里的误差却可能让“下界”超过最优值，于是证书本身失效。

还是看二次例，固定 $\nu=-3/4$。精确的内层解是 $\boldsymbol{x}(\nu)=(3/4,3/16)$。假设迭代停在

$$\tilde{\boldsymbol{x}}=(0.8,0.15).$$

此处的 Lagrange 函数值是

$$\mathcal{L}(\tilde{\boldsymbol{x}},\nu)=\frac{1}{2}(0.64+0.09)-0.75\,(0.8+0.15-1)=0.365+0.0375=0.4025.$$

这个数比 $f^\star=0.4$ 还大。如果把它当作下界，就会得出一个错误的结论，以为最优值不小于 0.4025。

要得到可靠的下界，必须从近似值中扣除一个经过证明的量。若内层函数有已知的曲率下界，用梯度残差就可以写出这个量。

引理 18.5　由梯度残差得到的认证下界　设 $\boldsymbol{D}=\mathbb{R}^n$，$\boldsymbol{\lambda}\ge\mathbf{0}$，函数 $\mathcal{L}(\cdot,\boldsymbol{\lambda},\boldsymbol{\nu})$ 可微且是 μ 强凸的，$\mu>0$。则对任意 $\tilde{\boldsymbol{x}}$，

$$q(\boldsymbol{\lambda},\boldsymbol{\nu})\ge\mathcal{L}(\tilde{\boldsymbol{x}},\boldsymbol{\lambda},\boldsymbol{\nu})-\frac{1}{2\mu}\left\|\nabla_{\boldsymbol{x}}\mathcal{L}(\tilde{\boldsymbol{x}},\boldsymbol{\lambda},\boldsymbol{\nu})\right\|_2^2. \tag{18.14}$$

证明　记 $\phi=\mathcal{L}(\cdot,\boldsymbol{\lambda},\boldsymbol{\nu})$，$\boldsymbol{r}=\nabla\phi(\tilde{\boldsymbol{x}})$。由 μ 强凸的一阶不等式，对任意 $\boldsymbol{y}$，

$$\phi(\boldsymbol{y})\ge\phi(\tilde{\boldsymbol{x}})+\langle\boldsymbol{r},\boldsymbol{y}-\tilde{\boldsymbol{x}}\rangle+\frac{\mu}{2}\|\boldsymbol{y}-\tilde{\boldsymbol{x}}\|_2^2.$$

右端是 $\boldsymbol{y}$ 的二次函数，在 $\boldsymbol{y}=\tilde{\boldsymbol{x}}-\boldsymbol{r}/\mu$ 处最小，最小值为 $\phi(\tilde{\boldsymbol{x}})-\|\boldsymbol{r}\|_2^2/(2\mu)$。于是对任意 $\boldsymbol{y}$，

$$\phi(\boldsymbol{y})\ge\phi(\tilde{\boldsymbol{x}})-\frac{1}{2\mu}\|\boldsymbol{r}\|_2^2.$$

对 $\boldsymbol{y}$ 取下确界即得。 ■

式 (18.14)的含义是：曲率下界 μ 限制了函数在 $\tilde{\boldsymbol{x}}$ 附近能下降多少，碗不会比它更平，所以梯度残差所能带来的下降有上限，我们把这个上限全部扣掉。

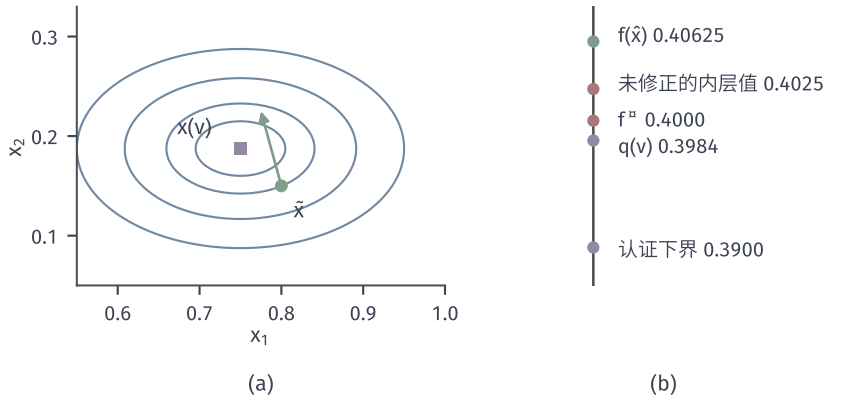
代入例子。Hessian 是 $\operatorname{diag}(1,4)$，取 $\mu=1$。梯度和扣除量分别是

$$\nabla_{\boldsymbol{x}}\mathcal{L}(\tilde{\boldsymbol{x}},\nu)=(x_1+\nu,\,4x_2+\nu)=(0.05,-0.15),\qquad \frac{1}{2\mu}\|\cdot\|_2^2=\frac{0.025}{2}=0.0125.$$

认证下界是

$$0.4025-0.0125=0.39.$$

它确实低于真正的 $q(-3/4)=0.3984$。图 18.8把这些数排在一起：未修正的内层值在 $f^\star$ 上方，认证下界在 q 下方。把它和 $f(\hat{\boldsymbol{x}})=0.40625$ 配对，得到的候选间隙是 0.01625，比精确内层的 0.0078 宽，但它是可信的。



18.1 下界的构造
18.2 弱对偶
18.3 凸共轭
18.3.1 共轭的定义与计算
18.3.2 共轭与最优性
18.3.3 对偶形式的推导
18.4 强对偶
18.5 最优性证书
18.6 本章小结

图 18.8 近似内层的方向。(a) 蓝线是 $\mathcal{L}(\cdot,-3/4)$ 的等高线，紫色方块是精确内层解 $\boldsymbol{x}(\nu)$，绿点是近似点 $\tilde{\boldsymbol{x}}$，绿色箭头是负梯度方向。(b) 数轴上由下往上是认证下界、精确的 $q(\nu)$、$f^\star$、未修正的内层值和可行点的目标值；未修正的内层值高于 $f^\star$，不能当作下界。

式中的 μ 必须是真正的曲率下界。若误把 $\mathcal{L}$ 的最大曲率 4 当作 μ，扣除量只有 $0.025/8 = 0.003125$，得到 0.399375，已经超过真正的 $q = 0.3984$，证书不再成立。当内层没有已知的强凸常数，或者 $\boldsymbol{D}$ 不是全空间时，这个引理不能直接使用；此时内层的近似值只能算是一个估计，不能写进误差证书。

18.3 凸共轭

计算对偶函数时，内层总是“目标加上一个线性项，再取下确界”。线性等式约束 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 的对偶函数就是

$$q(\boldsymbol{\nu}) = \inf_{\boldsymbol{x}} \bigl\{ f(\boldsymbol{x}) + \langle \boldsymbol{A}^{\mathsf{T}}\boldsymbol{\nu}, \boldsymbol{x} \rangle \bigr\} - \boldsymbol{b}^{\mathsf{T}}\boldsymbol{\nu}.$$

能否把“f 加线性项后的下确界”事先算好，以后遇到不同的约束时直接取用？这个运算单独拿出来，就是凸共轭。

18.3.1 共轭的定义与计算

下确界 $\inf_{\boldsymbol{x}}\{f(\boldsymbol{x}) + \langle \boldsymbol{c}, \boldsymbol{x} \rangle\}$ 有一个直观的图景。固定斜率 $\boldsymbol{y}$，拿一把这个斜率的直尺从下方往上顶，顶到碰到 f 为止。这把直尺就是斜率为 $\boldsymbol{y}$ 的最高仿射下界。要求直线 $\langle \boldsymbol{y}, \boldsymbol{x} \rangle - \beta$ 处处不超过 f，等价于对所有 $\boldsymbol{x}$ 有

$$\beta \geq \langle \boldsymbol{y}, \boldsymbol{x} \rangle - f(\boldsymbol{x}).$$

最小的 β 是右端对 $\boldsymbol{x}$ 的上确界，这就是下面的定义。

定义 18.6 凸共轭 设 $f:\mathbb{R}^n\to\mathbb{R}\cup\{+\infty\}$ 是适当函数。它的凸共轭（convex conjugate）是

$$f^*(\boldsymbol{y})=\sup_{\boldsymbol{x}\in\operatorname{dom} f}\{\langle \boldsymbol{y},\boldsymbol{x}\rangle - f(\boldsymbol{x})\}, \tag{18.15}$$

取值于 $\mathbb{R}\cup\{+\infty\}$。

记号上要小心，f^* 是共轭函数，$f^\star$ 是最优值，两者不是一回事。对固定的 $\boldsymbol{x}$，$\langle \boldsymbol{y},\boldsymbol{x}\rangle - f(\boldsymbol{x})$ 是 $\boldsymbol{y}$ 的仿射函数，f^* 是它们的上确界，所以无论 f 是否凸，f^* 总是凸的。这与定理 18.3是同一个论证。

图 18.9(a) 取 $f(x)=x^2$，斜率 $y=2$。过原点的点线 $2x$ 在 $x=1$ 处比 f 高出最多，这个最大的竖直距离是 1。把点线向下平移 1，得到切线 $2x-1$，它与竖轴的交点是 $-f^*(2)$。所以 $f^*(y)$ 是把斜率 y 的直线降到 f 之下需要降多少。

也可以把 $\boldsymbol{y}$ 读成价格，把 $f(\boldsymbol{x})$ 读成生产 $\boldsymbol{x}$ 的成本，于是 $f^*(\boldsymbol{y})$ 是价格 $\boldsymbol{y}$ 下能得到的最大利润。这个类比说明了为什么 f^* 对 $\boldsymbol{y}$ 是凸的：价格上涨时，厂商可以调整产量，利润的增长比线性更快。类比的边界在于 $\boldsymbol{x}$ 可以取负值，f 也不必是真实的成本。

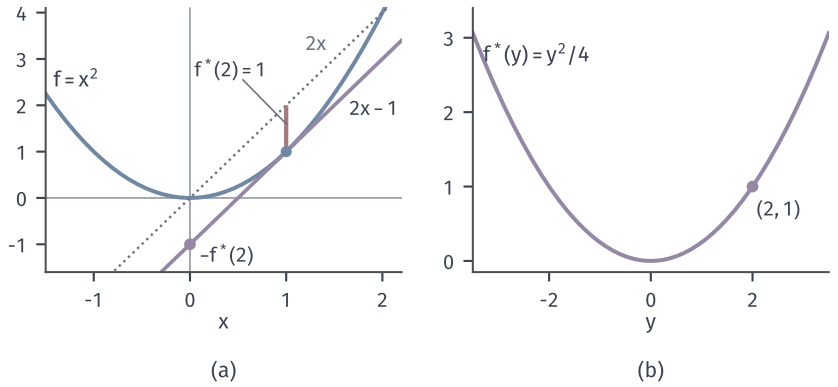


图 18.9 共轭是最高仿射下界的截距。(a) 蓝线是 $f(x)=x^2$，灰色点线是 $y=2$ 的直线 $2x$，红色线段是它与 f 的最大竖直距离 $f^*(2)=1$，紫线是下移后的切线，紫点是截距 $-f^*(2)$。(b) 紫线是共轭函数 $f^*(y)=y^2/4$，紫点对应 $y=2$。

下面计算三个基本的共轭，每个都要回答一个问题：f^* 在哪些 $\boldsymbol{y}$ 上取有限值。

正定二次函数 设 $\boldsymbol{Q}\in\mathbb{R}^{n\times n}$ 对称正定，$f(\boldsymbol{x})=\frac{1}{2}\boldsymbol{x}^\top\boldsymbol{Q}\boldsymbol{x}$。对 $\boldsymbol{x}$ 配方，令 $\boldsymbol{w}=\boldsymbol{x}-\boldsymbol{Q}^{-1}\boldsymbol{y}$，得到

$$\langle \boldsymbol{y},\boldsymbol{x}\rangle - \frac{1}{2}\boldsymbol{x}^\top\boldsymbol{Q}\boldsymbol{x} = \frac{1}{2}\boldsymbol{y}^\top\boldsymbol{Q}^{-1}\boldsymbol{y} - \frac{1}{2}\boldsymbol{w}^\top\boldsymbol{Q}\boldsymbol{w}.$$

第二项非正，在 $\boldsymbol{w}=\mathbf{0}$ 时取零，于是

$$f^{*}(\boldsymbol{y})=\frac{1}{2}\boldsymbol{y}^{\top}\boldsymbol{Q}^{-1}\boldsymbol{y}. \tag{18.16}$$

正定性保证上确界在每个 $\boldsymbol{y}$ 上都有限。$f(x)=x^{2}$ 相当于 $Q=2$，式 (18.16)给出 $f^{*}(y)=y^{2}/4$，$f^{*}(2)=1$，与图一致。

若 $\boldsymbol{Q}$ 只是半正定，f^{*} 的有限范围会缩小。例如 $\mathbb{R}^{2}$ 上的 $f(\boldsymbol{x})=\frac{1}{2}x_{1}^{2}$，只要 $y_{2}\neq 0$，沿 x_{2} 方向无限走，$\langle \boldsymbol{y},\boldsymbol{x}\rangle$ 就趋于 $+\infty$，所以 $f^{*}(\boldsymbol{y})=+\infty$；只有 $y_{2}=0$ 时，$f^{*}(\boldsymbol{y})=\frac{1}{2}y_{1}^{2}$。

最极端的情形是线性函数 $f(\boldsymbol{x})=\langle \boldsymbol{a},\boldsymbol{x}\rangle$。上确界 $\sup_{\boldsymbol{x}}\langle \boldsymbol{y}-\boldsymbol{a},\boldsymbol{x}\rangle$ 只有 $\boldsymbol{y}=\boldsymbol{a}$ 时有限，此时为 0。这正是线性规划对偶中出现等式约束的原因。

范数　设 $\|\cdot\|$ 是 $\mathbb{R}^{n}$ 上的一个范数。为了表述结果，先定义它的**对偶范数**（dual norm）：

$$\|\boldsymbol{y}\|_{*}=\sup_{\|\boldsymbol{x}\|\le 1}\langle \boldsymbol{y},\boldsymbol{x}\rangle. \tag{18.17}$$

由定义，对所有 $\boldsymbol{x}$，

$$\langle \boldsymbol{y},\boldsymbol{x}\rangle\le\|\boldsymbol{y}\|_{*}\|\boldsymbol{x}\|.$$

现在求 $f(\boldsymbol{x})=\|\boldsymbol{x}\|$ 的共轭，分两种情形。若 $\|\boldsymbol{y}\|_{*}\le 1$，由上式，线性项不超过范数，差值不大于零，并在 $\boldsymbol{x}=\mathbf{0}$ 取到零，上确界为 0。若 $\|\boldsymbol{y}\|_{*}>1$，存在 $\|\boldsymbol{x}_{0}\|\le 1$ 使 $\langle \boldsymbol{y},\boldsymbol{x}_{0}\rangle>1$，于是线性项超过范数；沿 $s\boldsymbol{x}_{0}$ 放大，差值随 s 线性增长，趋于 $+\infty$。

合起来，范数的共轭是对偶范数单位球的约束指标函数：

$$f^{*}(\boldsymbol{y})=\iota_{\{\|\boldsymbol{y}\|_{*}\le 1\}}(\boldsymbol{y}). \tag{18.18}$$

图 18.10(a) 和 (b) 是一元情形 $f(x)=|x|$。斜率的绝对值不超过 1 的直线都能放在折线下方，斜率 1.5 的直线在 $x>0$ 一侧无论怎样下移，最终都会越过 $|x|$。

集合的约束指标函数　设 $\boldsymbol{C}$ 非空。由定义，

$$\iota_{\boldsymbol{C}}^{*}(\boldsymbol{y})=\sup_{\boldsymbol{x}\in\boldsymbol{C}}\langle \boldsymbol{y},\boldsymbol{x}\rangle=:\sigma_{\boldsymbol{C}}(\boldsymbol{y}), \tag{18.19}$$

$\sigma_{\boldsymbol{C}}$ 称为 $\boldsymbol{C}$ 的**支撑函数**（support function）。它回答：沿方向 $\boldsymbol{y}$ 看，集合最远伸到哪里。集合有界时它处处有限，无界时在某些方向上可能为 $+\infty$。

一元的例子是 $\boldsymbol{C} = [-1, 2]$。$y \geq 0$ 时最远点是 2，$y < 0$ 时最远点是 -1，所以

$$\sigma_{\boldsymbol{C}}(y) = \max\{2y, -y\},$$

这是图 18.10(c) 的折线。

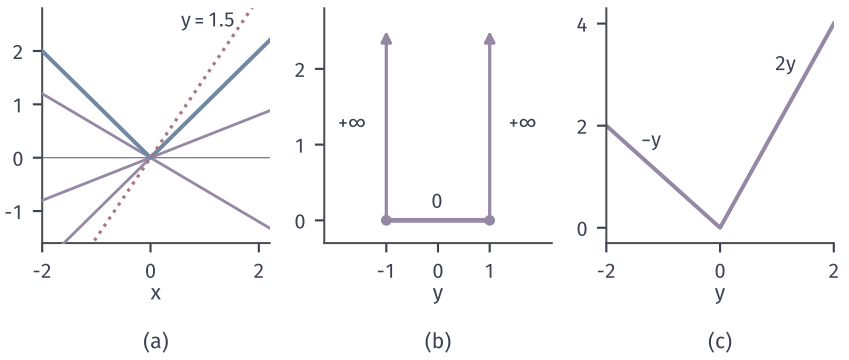


图 18.10 范数与集合的共轭。(a) 蓝线是 $|x|$，紫线是斜率 $-0.6, 0.4, 1$ 的直线，都在折线下方；红色点线斜率 1.5，不能下移成下界。(b) $|x|$ 的共轭：在 $[-1, 1]$ 上为 0，其余为 $+\infty$。(c) 集合 $[-1, 2]$ 的支撑函数 $\max\{2y, -y\}$。

二维的例子能同时看到范数和支撑函数的关系。取 $\boldsymbol{C}$ 为 ℓ_1 单位球，$\boldsymbol{y} = (2, 1)$。线性函数在多面体上的最大值在顶点取得，比较四个顶点 $(\pm 1, 0), (0, \pm 1)$，得到

$$\sigma_{\boldsymbol{C}}(\boldsymbol{y}) = \max\{2, -2, 1, -1\} = 2 = \|\boldsymbol{y}\|_\infty.$$

一般地，ℓ_1 单位球的支撑函数就是 ℓ_∞ 范数，也就是说 ℓ_1 与 ℓ_∞ 互为对偶范数。

图 18.11(a) 中，法向量为 $\boldsymbol{y}$ 的直线沿 $\boldsymbol{y}$ 方向平移，在 $(1, 0)$ 处最后一次碰到菱形。图 18.11(b) 画出了对偶范数的单位球：紫点 $(0.6, 0.4)$ 在方块内，线性项处处不超过 ℓ_1 范数；红点 $(1.4, 0.8)$ 在方块外，取 $\boldsymbol{x} = (1, 0)$，线性项等于 1.4，超过 $\|\boldsymbol{x}\|_1 = 1$。

18.1 下界的构造
18.2 弱对偶
18.3 凸共轭
18.3.1 共轭的定义与计算
18.3.2 共轭与最优性
18.3.3 对偶形式的推导
18.4 强对偶
18.5 最优性证书
18.6 本章小结

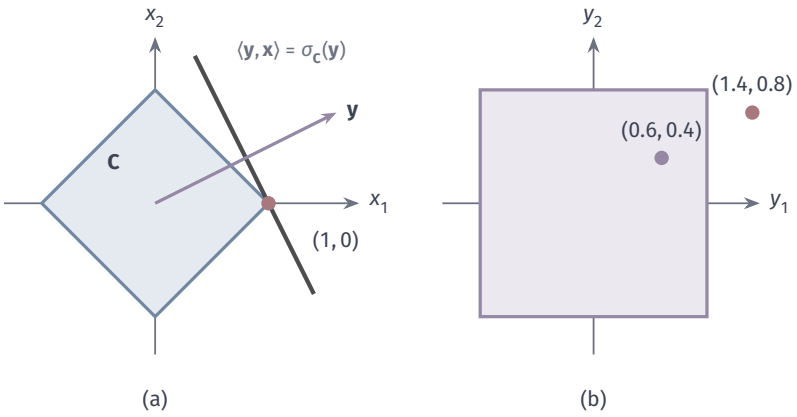


图 18.11 支撑函数与对偶范数。(a) 浅蓝菱形是 ℓ_1 单位球 $\boldsymbol{C}$，紫色箭头是方向 $\boldsymbol{y} = (2,1)$，深灰粗线是在红点 $(1,0)$ 处碰到 $\boldsymbol{C}$ 的直线 $\langle \boldsymbol{y}, \boldsymbol{x}\rangle = \sigma_{\boldsymbol{C}}(\boldsymbol{y}) = 2$。(b) 浅紫方块是 $\|\boldsymbol{y}\|_\infty \le 1$，方块内的紫点使共轭为 0，方块外的红点使共轭为 $+\infty$。

表 18.1汇总了这些结果，并把标量放缩算进去。这些函数常作为作用在辅助变量 $\boldsymbol{z}$ 上的惩罚项，所以表中用 $\boldsymbol{z}$ 和 $\boldsymbol{\nu}$ 作变量。它显示出硬约束与软惩罚在对偶一侧的关系：硬约束 $\boldsymbol{z} = \boldsymbol{0}$ 的乘子完全自由，二次惩罚让乘子带一个二次代价，范数惩罚让乘子落在一个球内。

原函数 $g(\boldsymbol{z})$	共轭 $g^*(\boldsymbol{\nu})$	有限范围
$\frac{\rho}{2}\|\boldsymbol{z}\|_2^2$ $(\rho > 0)$	$\frac{1}{2\rho}\|\boldsymbol{\nu}\|_2^2$	全空间
$\gamma\|\boldsymbol{z}\|$ $(\gamma > 0)$	$\iota_{\{\|\boldsymbol{\nu}\|_* \le \gamma\}}(\boldsymbol{\nu})$	对偶范数球
$\iota_{\{\boldsymbol{0}\}}(\boldsymbol{z})$	0	全空间
$\iota_{\boldsymbol{C}}(\boldsymbol{z})$	$\sigma_{\boldsymbol{C}}(\boldsymbol{\nu})$	由 $\boldsymbol{C}$ 决定
$\langle \boldsymbol{a}, \boldsymbol{z}\rangle$	$\iota_{\{\boldsymbol{a}\}}(\boldsymbol{\nu})$	单点 $\boldsymbol{a}$

表 18.1 常用函数的共轭。第一行由式 (18.16)取 $\boldsymbol{Q} = \rho\boldsymbol{I}$ 得到，第二行由式 (18.18)放缩得到。

18.3.2 共轭与最优性

共轭除了用来计算，还能描述一个点上的最优性。上确界不小于其中任何一项，由此直接得到一个不等式，它在共轭对偶中的作用，相当于弱对偶在 Lagrange 对偶中的作用。对任意 $\boldsymbol{x} \in \operatorname{dom} f$ 和任意 $\boldsymbol{y}$，

$$f(\boldsymbol{x}) + f^*(\boldsymbol{y}) \ge \langle \boldsymbol{x}, \boldsymbol{y}\rangle. \tag{18.20}$$

这称为Fenchel–Young 不等式（Fenchel–Young inequality）。

它的几何含义是：直线 $\langle \boldsymbol{y}, \cdot \rangle - f^*(\boldsymbol{y})$ 是 f 的下界，式 (18.20)是它在 $\boldsymbol{x}$ 处的值不超过 $f(\boldsymbol{x})$。两端的差就是 $\boldsymbol{x}$ 处 f 与这条直线之间的竖直距离。图 18.12(a) 中 $f(x) = x^2$，$x = 0.5$，$y = 2$，差为

$$0.25 + 1 - 1 = 0.25.$$

什么时候取等？第 11章定义过次梯度：$\boldsymbol{y} \in \partial f(\boldsymbol{x})$ 是指对所有 $\boldsymbol{x}'$，

$$f(\boldsymbol{x}') \geq f(\boldsymbol{x}) + \langle \boldsymbol{y}, \boldsymbol{x}' - \boldsymbol{x} \rangle.$$

这正是说直线在 $\boldsymbol{x}$ 处贴着 f。

定理 18.7 Fenchel–Young 取等条件 设 f 是适当的凸函数，$\boldsymbol{x} \in \operatorname{dom} f$。则

$$\begin{aligned} & f(\boldsymbol{x}) + f^*(\boldsymbol{y}) = \langle \boldsymbol{x}, \boldsymbol{y} \rangle \\ \iff \quad & \boldsymbol{y} \in \partial f(\boldsymbol{x}). \end{aligned} \tag{18.21}$$

证明 由定义，左边的等式等价于 $\boldsymbol{x}$ 达到式 (18.15)中的上确界，也就是对所有 $\boldsymbol{x}' \in \operatorname{dom} f$，

$$\langle \boldsymbol{y}, \boldsymbol{x}' \rangle - f(\boldsymbol{x}') \leq \langle \boldsymbol{y}, \boldsymbol{x} \rangle - f(\boldsymbol{x}).$$

移项得到

$$f(\boldsymbol{x}') \geq f(\boldsymbol{x}) + \langle \boldsymbol{y}, \boldsymbol{x}' - \boldsymbol{x} \rangle.$$

$\boldsymbol{x}' \notin \operatorname{dom} f$ 时这个不等式自动成立，所以它正是次梯度的定义。 ■

光滑点上次梯度只有一个，取等的 y 也只有一个，图 18.12(a) 中 $x = 1$ 的切线斜率 2 就是这样。尖点上次梯度有多个，图 18.12(b) 中 $|x|$ 在 $x = 0$ 处，所有 $y \in [-1, 1]$ 都取等：

$$|0| + f^*(y) = 0 + 0 = 0 \cdot y.$$

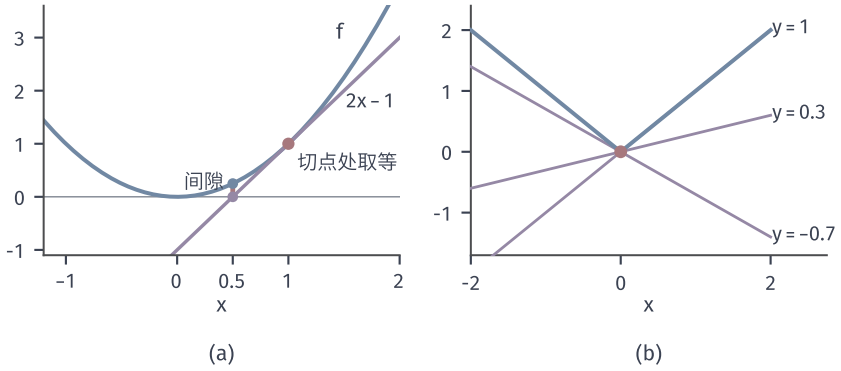


图 18.12 Fenchel–Young 不等式的几何。(a) 蓝线是 $f(x)=x^2$，紫线是 $y=2$ 的最高下界 $2x-1$，红色短线是 $x=0.5$ 处的间隙 0.25，红点 $x=1$ 处间隙为零。(b) 蓝线是 $|x|$，紫线是 $y=-0.7, 0.3, 1$ 的下界，它们都在红点 $x=0$ 处贴着折线，所以这些 y 都是 0 处的次梯度。

共轭把 f 变成了一族下方的直线。这些直线够不够重建 f？把共轭再做一次，得到**双共轭**（biconjugate）

$$f^{**}(\boldsymbol{x}) = \sup_{\boldsymbol{y}} \{\langle \boldsymbol{y}, \boldsymbol{x}\rangle - f^{*}(\boldsymbol{y})\}, \tag{18.22}$$

它是 f 全部仿射下界的上确界。由式 (18.20)，总有 $f^{**} \le f$。反过来的不等式需要在 f 上方的每个缺口处放进一条直线，工具是分离定理。

定理 18.8 点与闭凸集的严格分离 设 $\boldsymbol{S} \subseteq \mathbb{R}^N$ 非空、闭、凸，$\boldsymbol{z} \notin \boldsymbol{S}$。则存在 $\boldsymbol{a} \neq \boldsymbol{0}$ 和 $\beta \in \mathbb{R}$，使得对所有 $\boldsymbol{w} \in \boldsymbol{S}$，

$$\langle \boldsymbol{a}, \boldsymbol{w}\rangle \le \beta < \langle \boldsymbol{a}, \boldsymbol{z}\rangle. \tag{18.23}$$

证明 第 11章已得到投影 $\boldsymbol{p} = \Pi_{\boldsymbol{S}}(\boldsymbol{z})$ 的存在性及其刻画：

$$\langle \boldsymbol{z}-\boldsymbol{p}, \boldsymbol{w}-\boldsymbol{p}\rangle \le 0 \qquad \text{对所有 } \boldsymbol{w} \in \boldsymbol{S}.$$

令 $\boldsymbol{a} = \boldsymbol{z} - \boldsymbol{p}$，$\beta = \langle \boldsymbol{a}, \boldsymbol{p}\rangle$。$\boldsymbol{z} \notin \boldsymbol{S}$ 而 $\boldsymbol{p} \in \boldsymbol{S}$，所以 $\boldsymbol{a} \neq \boldsymbol{0}$。上式就是 $\langle \boldsymbol{a}, \boldsymbol{w}\rangle \le \beta$。又因为

$$\langle \boldsymbol{a}, \boldsymbol{z}\rangle = \beta + \|\boldsymbol{a}\|_2^2 > \beta,$$

式 (18.23)成立。 ■

超平面 $\{\boldsymbol{w} : \langle \boldsymbol{a}, \boldsymbol{w}\rangle = \beta\}$ 称为**分离超平面**（separating hyperplane）。把分离定理用到函数上，要把函数变成集合。函数 f 的**上图**（epigraph）是

$$\operatorname{epi} f = \{(\boldsymbol{x}, r) : \boldsymbol{x} \in \operatorname{dom} f,\ r \geq f(\boldsymbol{x})\}.$$

f 凸时上图凸。f 下半连续时上图闭：若 $(\boldsymbol{x}^{(k)}, r^{(k)}) \to (\boldsymbol{x}, r)$ 且 $r^{(k)} \geq f(\boldsymbol{x}^{(k)})$，则 $r \geq \liminf_k f(\boldsymbol{x}^{(k)}) \geq f(\boldsymbol{x})$。

定理 18.9　Fenchel–Moreau　设 $f : \mathbb{R}^n \to \mathbb{R} \cup \{+\infty\}$ 是适当、下半连续的凸函数，则 $f^{**} = f$。

证明　已知 $f^{**} \leq f$，只需证明：对任意 $\boldsymbol{x}$ 和任意实数 $r < f(\boldsymbol{x})$，存在仿射下界 $\ell \leq f$ 使 $\ell(\boldsymbol{x}) > r$。因为若 $\ell(\cdot) = \langle \boldsymbol{y}, \cdot\rangle - \beta'$ 是这样的下界，由 $\ell \leq f$ 得 $f^*(\boldsymbol{y}) \leq \beta'$，于是 $f^{**}(\boldsymbol{x}) \geq \ell(\boldsymbol{x}) > r$。

点 $(\boldsymbol{x}, r)$ 不在闭凸集 $\operatorname{epi} f$ 中。对它应用定理 18.8，并把分离向量取相反数，得到 $(\boldsymbol{a}, b) \neq \boldsymbol{0}$ 和 β，使对所有 $(\boldsymbol{x}', r') \in \operatorname{epi} f$，

$$\langle \boldsymbol{a}, \boldsymbol{x}'\rangle + b r' \geq \beta > \langle \boldsymbol{a}, \boldsymbol{x}\rangle + b r.$$

上图沿 r' 向上无界，所以 $b \geq 0$。

情形一：$b > 0$。取 $r' = f(\boldsymbol{x}')$ 并除以 b，得到仿射下界

$$\ell(\boldsymbol{x}') = \frac{\beta - \langle \boldsymbol{a}, \boldsymbol{x}'\rangle}{b} \leq f(\boldsymbol{x}'),$$

而分离的严格不等式正是 $\ell(\boldsymbol{x}) > r$。若 $\boldsymbol{x} \in \operatorname{dom} f$，一定属于这一情形，否则 $b = 0$ 时取 $\boldsymbol{x}' = \boldsymbol{x}$，$r' = f(\boldsymbol{x})$，得到矛盾：

$$\langle \boldsymbol{a}, \boldsymbol{x}\rangle \geq \beta > \langle \boldsymbol{a}, \boldsymbol{x}\rangle.$$

情形二：$b = 0$，此时 $\boldsymbol{x} \notin \operatorname{dom} f$，并且对所有 $\boldsymbol{x}' \in \operatorname{dom} f$ 有 $\beta - \langle \boldsymbol{a}, \boldsymbol{x}'\rangle \leq 0$。在 $\operatorname{dom} f$ 中任取一点用情形一，得到某个仿射下界 $\ell_0 \leq f$。对 $\varepsilon > 0$ 令

$$\ell_\varepsilon(\boldsymbol{x}') = \ell_0(\boldsymbol{x}') + \frac{\beta - \langle \boldsymbol{a}, \boldsymbol{x}'\rangle}{\varepsilon}.$$

在 $\operatorname{dom} f$ 上第二项非正，所以 $\ell_\varepsilon \leq f$。在点 $\boldsymbol{x}$ 处 $\beta - \langle \boldsymbol{a}, \boldsymbol{x}\rangle > 0$，$\varepsilon$ 足够小时 $\ell_\varepsilon(\boldsymbol{x}) > r$。 ■

18.1 下界的构造
18.2 弱对偶
18.3 凸共轭
18.3.1 共轭的定义与计算
18.3.2 共轭与最优性
18.3.3 对偶形式的推导
18.4 强对偶
18.5 最优性证书
18.6 本章小结

定理的三个条件各有作用。图 18.13(a) 和 (b) 说明闭性的作用。$f = \iota_{(0,1)}$ 是凸函数，但不是下半连续的，因为端点处函数值跳到 $+\infty$。它的共轭和双共轭分别是

$$f^*(y) = \sup_{0<x<1} xy = \max\{y, 0\}, \qquad f^{**} = \iota_{[0,1]}.$$

双共轭补上了两个端点，因为仿射下界分辨不出开区间和它的闭包。

凸性的作用见图 18.13(c)。双井函数 $(x^2-1)^2$ 的双共轭在 $[-1,1]$ 上是 0，中间的鼓包被抹平了。一般地，只要 f 有仿射下界，f^{**} 就是 f 的最大的下半连续凸下界，仿射下界只能看到函数的凸的部分。

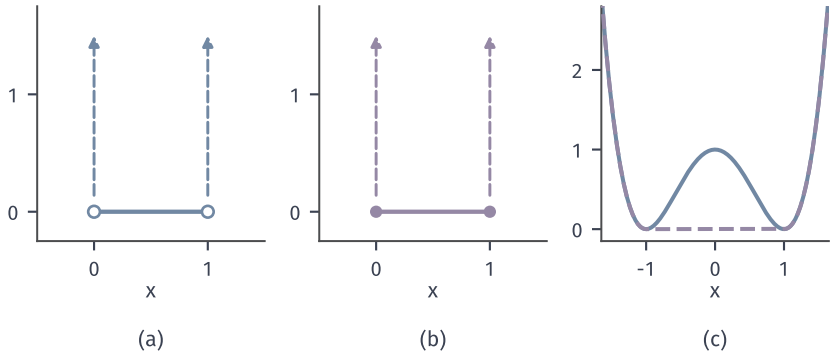


图 18.13　双共轭恢复什么。(a) $\iota_{(0,1)}$，两端的空心点表示不属于有效定义域，虚线箭头表示区间外为 $+\infty$。(b) 它的双共轭 $\iota_{[0,1]}$，端点变为实心。(c) 蓝线是双井函数 $(x^2-1)^2$，紫色虚线是数值计算的双共轭，在 $[-1,1]$ 上为零，在外侧与原函数重合。

定理 18.9说的是一个函数可以由它的仿射下界重建，并没有说某个约束问题的对偶间隙为零。后者涉及目标和约束的联合结构，要到下一节才能回答，两件事不能混淆。

18.3.3 对偶形式的推导

有了共轭，对偶函数可以按公式写出，不必每次重新配方。先看线性等式约束 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$，其中 $\boldsymbol{A} \in \mathbb{R}^{p\times n}$。把内层的线性项按定义 (18.15)改写：

$$\inf_{\boldsymbol{x}}\{f(\boldsymbol{x}) + \langle \boldsymbol{A}^{\top}\boldsymbol{\nu}, \boldsymbol{x}\rangle\} = -\sup_{\boldsymbol{x}}\{\langle -\boldsymbol{A}^{\top}\boldsymbol{\nu}, \boldsymbol{x}\rangle - f(\boldsymbol{x})\}.$$

右端的上确界是 $f^*(-\boldsymbol{A}^{\top}\boldsymbol{\nu})$，于是

$$q(\boldsymbol{\nu}) = -f^*(-\boldsymbol{A}^{\top}\boldsymbol{\nu}) - \boldsymbol{b}^{\top}\boldsymbol{\nu}. \tag{18.24}$$

符号要逐项记住：共轭的自变量带负号，因为 inf 变 sup 时线性项反号。式 (18.24)有限的条件是 $-\boldsymbol{A}^{\mathsf{T}}\boldsymbol{\nu} \in \operatorname{dom} f^*$，也就是说，共轭的有限范围就是对偶问题的隐含约束。

用二次例核对。$\boldsymbol{Q} = \operatorname{diag}(1,4)$，$\boldsymbol{A} = (1,1)$，$b = 1$。由式 (18.16)，

$$f^*(-\nu,-\nu) = \frac{1}{2}\Big(\nu^2 + \frac{\nu^2}{4}\Big) = \frac{5}{8}\nu^2.$$

代入式 (18.24)得到 $q(\nu) = -\frac{5}{8}\nu^2 - \nu$，与式 (18.6)相同。

复合形式 第 11章常见的目标是两部分之和，一部分作用在 $\boldsymbol{x}$ 上，另一部分作用在 $\boldsymbol{A}\boldsymbol{x}$ 上：

$$\min_{\boldsymbol{x}} \; F(\boldsymbol{x}) = f(\boldsymbol{x}) + g(\boldsymbol{A}\boldsymbol{x}), \tag{18.25}$$

其中 $g : \mathbb{R}^p \to \mathbb{R} \cup \{+\infty\}$ 是一个函数，不是约束函数 g_i，$\boldsymbol{A} \in \mathbb{R}^{p\times n}$。这个问题没有显式的约束，直接写 Lagrange 函数得不到任何东西。

办法是人为造出一条约束：引入辅助变量 $\boldsymbol{z} = \boldsymbol{A}\boldsymbol{x}$，把问题改写成

$$\min_{\boldsymbol{x},\boldsymbol{z}} \; f(\boldsymbol{x}) + g(\boldsymbol{z}) \quad \text{s.t.} \quad \boldsymbol{A}\boldsymbol{x} - \boldsymbol{z} = \boldsymbol{0}.$$

这是等价改写，最优值不变。给等式配乘子 $\boldsymbol{\nu} \in \mathbb{R}^p$，Lagrange 函数按 $\boldsymbol{x}$ 和 $\boldsymbol{z}$ 分成两部分：

$$\mathcal{L} = \big[f(\boldsymbol{x}) + \langle \boldsymbol{A}^{\mathsf{T}}\boldsymbol{\nu}, \boldsymbol{x}\rangle\big] + \big[g(\boldsymbol{z}) - \langle \boldsymbol{\nu}, \boldsymbol{z}\rangle\big].$$

两部分的下确界可以分别取。第一部分和前面相同，第二部分由共轭的定义得到：

$$\inf_{\boldsymbol{x}}\big[f(\boldsymbol{x}) + \langle \boldsymbol{A}^{\mathsf{T}}\boldsymbol{\nu}, \boldsymbol{x}\rangle\big] = -f^*(-\boldsymbol{A}^{\mathsf{T}}\boldsymbol{\nu}), \qquad \inf_{\boldsymbol{z}}\big[g(\boldsymbol{z}) - \langle \boldsymbol{\nu}, \boldsymbol{z}\rangle\big] = -g^*(\boldsymbol{\nu}).$$

于是得到Fenchel 对偶（Fenchel duality）：

$$\max_{\boldsymbol{\nu}} \; q(\boldsymbol{\nu}) = -f^*(-\boldsymbol{A}^{\mathsf{T}}\boldsymbol{\nu}) - g^*(\boldsymbol{\nu}). \tag{18.26}$$

图 18.14是这个推导的结构。注意 $\boldsymbol{\nu}$ 在两项里符号相反，这是从 $\boldsymbol{A}\boldsymbol{x} - \boldsymbol{z}$ 的两个系数来的：换成 $\boldsymbol{z} - \boldsymbol{A}\boldsymbol{x}$，等于把 $\boldsymbol{\nu}$ 换成 $-\boldsymbol{\nu}$，最优值不变。

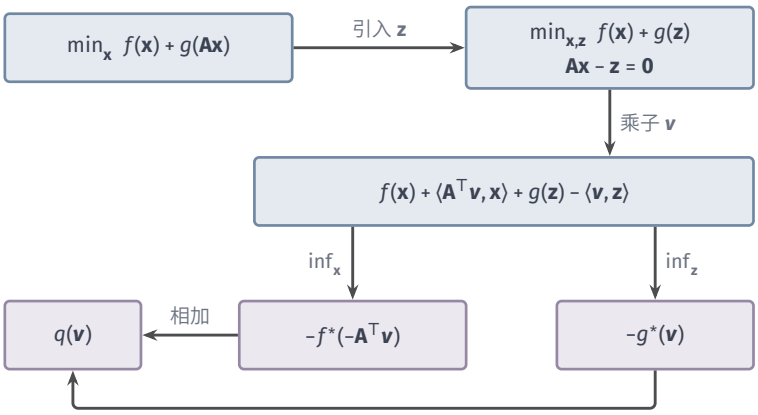


图 18.14 复合问题的对偶形式怎样得到。浅蓝框是原变量一侧的表达，浅紫框是对偶一侧的量：引入 $\boldsymbol{z}$，配乘子 $\boldsymbol{\nu}$，再对 $\boldsymbol{x}$ 和 $\boldsymbol{z}$ 分别取下确界，得到两个共轭。

式 (18.26)的弱对偶也可以直接从 Fenchel–Young 不等式看出。对任意 $\boldsymbol{x}$ 和 $\boldsymbol{\nu}$，把式 (18.20)分别用于 $(f, \boldsymbol{x}, -\boldsymbol{A}^{\top}\boldsymbol{\nu})$ 和 $(g, \boldsymbol{A}\boldsymbol{x}, \boldsymbol{\nu})$，得到

$$f(\boldsymbol{x}) + f^{*}(-\boldsymbol{A}^{\top}\boldsymbol{\nu}) \geq -\langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{\nu}\rangle, \qquad g(\boldsymbol{A}\boldsymbol{x}) + g^{*}(\boldsymbol{\nu}) \geq \langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{\nu}\rangle.$$

两式相加，右端抵消，即得 $F(\boldsymbol{x}) \geq q(\boldsymbol{\nu})$。

下面算一个例子，目标沿用预算例的二次项，第二项换成绝对值惩罚：

$$\min_{\boldsymbol{x}\in\mathbb{R}^2} \frac{1}{2}\left[(x_1-2)^2 + (x_2-1)^2\right] + |x_1 + x_2|.$$

这里 $\boldsymbol{A} = (1,1)$，$g = |\cdot|$，$\boldsymbol{a} = (2,1)$，$f(\boldsymbol{x}) = \frac{1}{2}\|\boldsymbol{x}-\boldsymbol{a}\|_2^2$。

先求 f^{*}。上确界的驻点是 $\boldsymbol{x} = \boldsymbol{a} + \boldsymbol{y}$，代入得到

$$f^{*}(\boldsymbol{y}) = \langle \boldsymbol{y}, \boldsymbol{a}\rangle + \frac{1}{2}\|\boldsymbol{y}\|_2^2.$$

取 $\boldsymbol{y} = -\boldsymbol{A}^{\top}\nu = (-\nu, -\nu)$，有

$$f^{*}(-\boldsymbol{A}^{\top}\nu) = -3\nu + \nu^2.$$

由表 18.1，$g^{*} = \iota_{[-1,1]}$，它的作用是把 ν 限制在 $[-1,1]$ 内。于是对偶问题是

$$\max_{-1\leq\nu\leq 1} \; 3\nu - \nu^2.$$

无约束最大点 $\nu = 3/2$ 在区间外，所以 $\nu^{\star} = 1$，对偶值是 $3 - 1 = 2$。

回到原变量。由 $\boldsymbol{x}$ 的驻定条件 $\boldsymbol{x} - \boldsymbol{a} + \boldsymbol{A}^{\top}\nu = \boldsymbol{0}$，得到

$$\boldsymbol{x} = \boldsymbol{a} - \boldsymbol{A}^{\top}\nu^{\star} = (1, 0).$$

18.1 下界的构造
18.2 弱对偶
18.3 凸共轭
18.4 强对偶
18.4.1 Slater 条件
18.4.2 共轭对偶的正则条件
18.4.3 间隙与达到的区别
18.5 最优性证书
18.6 本章小结

核对目标值：$F(1,0)=\frac{1}{2}(1+1)+1=2$，等于对偶值。根据弱对偶，$(1,0)$ 是最优解。这里零间隙是算出来的；一般情况下式 (18.26)只建立了对偶的表达，零间隙能否成立，要看下一节的条件。

18.4 强对偶

前面的二次例、预算例和绝对值例中，最好的下界都恰好等于最优值。于是要问：这在什么时候成立？当 $d^\star=f^\star$ 时，称**强对偶**成立，也说零间隙。这里有三件容易混淆的事要分开：两个最优值相等，原始最优点存在，最优乘子存在。

联合集合与分离 为了看清楚乘子从哪里来，把目标和约束放到同一个空间里。定义联合集合

$$\boldsymbol{A}=\big\{(\boldsymbol{u},\boldsymbol{w},t)：\text{存在 }\boldsymbol{x}\in\boldsymbol{D}\text{ 使 }g_i(\boldsymbol{x})\le u_i,\ h_j(\boldsymbol{x})=w_j,\ f(\boldsymbol{x})\le t\big\}. \tag{18.27}$$

$(\boldsymbol{u},\boldsymbol{w})$ 是约束右端允许的松动量，t 是能够达到的目标值。原问题的最优值是集合 $\boldsymbol{A}$ 在 $(\boldsymbol{u},\boldsymbol{w})=\boldsymbol{0}$ 这条竖线上的最低高度。

$\boldsymbol{\lambda}\ge\boldsymbol{0}$ 时，对偶函数可以用这个集合重写：

$$q(\boldsymbol{\lambda},\boldsymbol{\nu})=\inf_{(\boldsymbol{u},\boldsymbol{w},t)\in\boldsymbol{A}}\big\{t+\langle\boldsymbol{\lambda},\boldsymbol{u}\rangle+\langle\boldsymbol{\nu},\boldsymbol{w}\rangle\big\}.$$

所以 q 是用法向量 $(\boldsymbol{\lambda},\boldsymbol{\nu},1)$ 的超平面从下方托住 $\boldsymbol{A}$ 时，在竖轴上的高度。f,g_i 凸且 h_j 仿射时 $\boldsymbol{A}$ 是凸集，分离定理就有了用武之地。

设想把一张纸从下方贴到 $\boldsymbol{A}$ 上，碰在点 $(\boldsymbol{0},f^\star)$ 处。如果纸不是竖直的，就可以把法向量的 t 分量归一成 1，其余分量就是乘子，竖轴上的高度就是 $f^\star$，强对偶成立。所以问题的关键是这张纸是否竖直。

图 18.15对比两种情形，只有一条不等式，$\boldsymbol{A}$ 位于平面上。(a) 是一元例，$\boldsymbol{A}$ 的下边界是最优值函数 $v(u)=\frac{1}{2}\max\{1-u,0\}^2$。它在 $u=0$ 的两侧都有定义，切线 $t=\frac{1}{2}-u$ 的斜率给出 $\lambda^\star=1$。

(b) 是问题 $\min x$，约束 $x^2\le u$。$u<0$ 时不可行，$v(u)=-\sqrt{u}$ 在 $u=0$ 处切线竖直。能托住 $\boldsymbol{A}$ 并经过原点的只有竖直线，它不对应任何有限的乘子。

18.1 下界的构造
18.2 弱对偶
18.3 凸共轭
18.4 强对偶
18.4.1 Slater 条件
18.4.2 共轭对偶的正则条件
18.4.3 间隙与达到的区别
18.5 最优性证书
18.6 本章小结

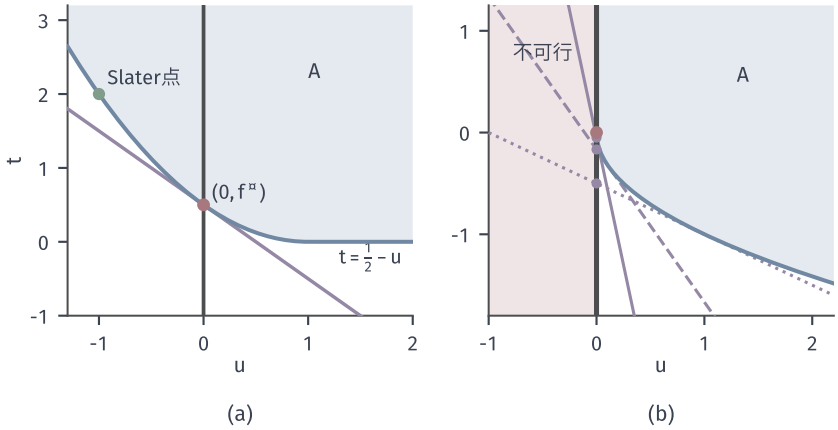


图 18.15 联合集合 $\boldsymbol{A}$（浅蓝）与托住它的直线。(a) 一元例：紫线 $t = \frac{1}{2} - u$ 在红点 $(0, f^\star)$ 处托住 $\boldsymbol{A}$，斜率对应 $\lambda^\star = 1$；绿点是 Slater 点 $x = 0$ 对应的 $(g, f) = (-1, 2)$，它在竖线 $u = 0$ 的左侧。(b) $\min x$，约束 $x^2 \le u$：浅红区域 $u < 0$ 不可行，$\boldsymbol{A}$ 的边界在红点处切线竖直，紫线是 $\lambda = 0.5, 1.5, 5$（点线、虚线、实线）的托线，交点高度 $-1/(4\lambda)$ 随 λ 增大升向 0，但能经过红点的只有深灰色竖线。

要排除竖直的纸，只需要 $\boldsymbol{A}$ 在竖线左侧确实有点，这正是图 18.15(a) 中绿点起的作用。

18.4.1 Slater 条件

把上面的想法写成条件。设 $f, g_i : \mathbb{R}^n \to \mathbb{R} \cup \{+\infty\}$ 是凸函数，等式约束仿射，写成 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$，其中 $\boldsymbol{A} \in \mathbb{R}^{p \times n}$。共同有效定义域是

$$\boldsymbol{D} = \operatorname{dom} f \cap \bigcap_i \operatorname{dom} g_i.$$

第 11章用 ri 表示相对内部，即在集合自身的仿射包内的内点。

定义 18.10 Slater 条件 若存在 $\bar{\boldsymbol{x}} \in \operatorname{ri} \boldsymbol{D}$，使

$$g_i(\bar{\boldsymbol{x}}) < 0, \quad i = 1, \dots, m, \qquad \boldsymbol{A}\bar{\boldsymbol{x}} = \boldsymbol{b}, \tag{18.28}$$

就称问题满足Slater 条件（Slater's condition），$\bar{\boldsymbol{x}}$ 称为 Slater 点。

条件的每一部分都有用处。严格不等式让点落在竖线左侧；等式约束无法严格，只要求满足；取在相对内部，是为了让定义域在 $\bar{\boldsymbol{x}}$ 周围留有余地，否则余量可能恰好被定义域的边缘吃掉。

三个例子都容易找到 Slater 点。一元例取 $\bar{x} = 0$，$g(\bar{x}) = -1 < 0$。预算例取 $\bar{\boldsymbol{x}} = (1/2, 1/2)$，它在 $\boldsymbol{D} = \mathbb{R}^2_+$ 的内部，且 $x_1 + x_2 - 2 = -1 < 0$。二次例没有不等式，取约束直线上的任一点。

证明要分离的不是闭集，$(\mathbf{0}, f^\star)$ 可能就在 $\boldsymbol{A}$ 的边界上。定理 18.8不够用，需要下面这个不要求闭性、也不要求严格的版本。

引理 18.11　点与凸集的分离　设 $\boldsymbol{S} \subseteq \mathbb{R}^N$ 非空、凸，$\boldsymbol{z} \notin \boldsymbol{S}$。则存在 $\boldsymbol{a} \neq \mathbf{0}$，使得对所有 $\boldsymbol{w} \in \boldsymbol{S}$，

$$\langle \boldsymbol{a}, \boldsymbol{w} \rangle \geq \langle \boldsymbol{a}, \boldsymbol{z} \rangle. \tag{18.29}$$

证明　$\mathbb{R}^N$ 的子集有可数稠密子集，取 $\boldsymbol{S}$ 中的这样一列点 $\boldsymbol{w}_1, \boldsymbol{w}_2, \ldots$。对每个 k，令 $\boldsymbol{S}_k$ 是 $\boldsymbol{w}_1, \ldots, \boldsymbol{w}_k$ 的凸组合全体。

$\boldsymbol{S}_k$ 是单纯形在连续映射下的像，所以是紧的，从而是闭集；它包含于凸集 $\boldsymbol{S}$，所以不含 $\boldsymbol{z}$。对 $\boldsymbol{S}_k$ 用定理 18.8，取相反数并归一化，得到单位向量 $\boldsymbol{a}_k$，使

$$\langle \boldsymbol{a}_k, \boldsymbol{w}_j \rangle > \langle \boldsymbol{a}_k, \boldsymbol{z} \rangle, \qquad j = 1, \ldots, k.$$

单位球面是紧集，$\boldsymbol{a}_k$ 有收敛子列，极限 $\boldsymbol{a}$ 仍是单位向量。固定 j，让 k 沿子列趋于无穷，得到

$$\langle \boldsymbol{a}, \boldsymbol{w}_j \rangle \geq \langle \boldsymbol{a}, \boldsymbol{z} \rangle.$$

$\{\boldsymbol{w}_j\}$ 在 $\boldsymbol{S}$ 中稠密，内积连续，所以式 (18.29)对全部 $\boldsymbol{w} \in \boldsymbol{S}$ 成立。 ■

定理 18.12　Slater 条件下的强对偶　设问题的 f, g_i 凸、等式约束仿射，满足 Slater 条件，且 $f^\star$ 有限。则

$$d^\star = f^\star, \tag{18.30}$$

并且对偶最优值被某组 $(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 达到，其中 $\boldsymbol{\lambda}^\star \geq \mathbf{0}$。

证明　第一步，选取工作空间。令 $\boldsymbol{V}$ 是 $\boldsymbol{D}$ 的仿射包的方向子空间，$\boldsymbol{W} = \{\boldsymbol{A}\boldsymbol{v} : \boldsymbol{v} \in \boldsymbol{V}\}$。对 $\boldsymbol{x} \in \boldsymbol{D}$，由 $\boldsymbol{A}\bar{\boldsymbol{x}} = \boldsymbol{b}$，有

$$\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b} = \boldsymbol{A}(\boldsymbol{x} - \bar{\boldsymbol{x}}) \in \boldsymbol{W}.$$

所以等式残差不会离开 $\boldsymbol{W}$，只需要在 $\mathbb{R}^m \times \boldsymbol{W} \times \mathbb{R}$ 中讨论。

第二步，构造被分离的集合。令 $\boldsymbol{S}$ 是满足下面条件的 $(\boldsymbol{u}, \boldsymbol{w}, t)$ 的全体：存在 $\boldsymbol{x} \in \boldsymbol{D}$，使 $g_i(\boldsymbol{x}) \leq u_i$，$\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b} = \boldsymbol{w}$，$f(\boldsymbol{x}) < t$。由 f, g_i 的

凸性和等式的仿射性，$\boldsymbol{S}$ 是凸集，并且它是非空的，因为 $\bar{\boldsymbol{x}} \in \boldsymbol{D}$。点 $(\boldsymbol{0}, \boldsymbol{0}, f^\star)$ 不在 $\boldsymbol{S}$ 中，否则存在可行点使 $f(\boldsymbol{x}) < f^\star$。

第三步，应用分离。由引理 18.11，存在不全为零的 $\boldsymbol{\lambda} \in \mathbb{R}^m$、$\boldsymbol{\nu} \in \boldsymbol{W}$、$\lambda_0 \in \mathbb{R}$，使对所有 $(\boldsymbol{u}, \boldsymbol{w}, t) \in \boldsymbol{S}$，

$$\langle \boldsymbol{\lambda}, \boldsymbol{u} \rangle + \langle \boldsymbol{\nu}, \boldsymbol{w} \rangle + \lambda_0 t \geq \lambda_0 f^\star.$$

$\boldsymbol{S}$ 中的点可以把 u_i 或 t 任意增大，若 $\lambda_i < 0$ 或 $\lambda_0 < 0$，左端会趋于 $-\infty$，所以 $\boldsymbol{\lambda} \geq \boldsymbol{0}$，$\lambda_0 \geq 0$。

任取 $\boldsymbol{x} \in \boldsymbol{D}$，取 $\boldsymbol{u} = (g_i(\boldsymbol{x}))_i$，$\boldsymbol{w} = \boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}$，$t = f(\boldsymbol{x}) + \varepsilon$，令 $\varepsilon \downarrow 0$，得到

$$\sum_i \lambda_i g_i(\boldsymbol{x}) + \langle \boldsymbol{\nu}, \boldsymbol{A}\boldsymbol{x} - \boldsymbol{b} \rangle + \lambda_0 f(\boldsymbol{x}) \geq \lambda_0 f^\star, \qquad \boldsymbol{x} \in \boldsymbol{D}.$$

第四步，证明 $\lambda_0 > 0$，也就是这张纸不竖直。设 $\lambda_0 = 0$。把 $\boldsymbol{x} = \bar{\boldsymbol{x}}$ 代入上式，等式项为零，得到

$$\sum_i \lambda_i g_i(\bar{\boldsymbol{x}}) \geq 0.$$

由 $g_i(\bar{\boldsymbol{x}}) < 0$ 和 $\boldsymbol{\lambda} \geq \boldsymbol{0}$，只能 $\boldsymbol{\lambda} = \boldsymbol{0}$。于是 $\boldsymbol{\nu} \neq \boldsymbol{0}$，并且上式变成对所有 $\boldsymbol{x} \in \boldsymbol{D}$，

$$\langle \boldsymbol{\nu}, \boldsymbol{A}(\boldsymbol{x} - \bar{\boldsymbol{x}}) \rangle \geq 0.$$

因为 $\bar{\boldsymbol{x}} \in \operatorname{ri} \boldsymbol{D}$，存在 $r > 0$，使对 $\boldsymbol{v} \in \boldsymbol{V}$，$\|\boldsymbol{v}\|_2 \leq r$，都有 $\bar{\boldsymbol{x}} + \boldsymbol{v} \in \boldsymbol{D}$。代入 $\pm\boldsymbol{v}$，得到 $\langle \boldsymbol{\nu}, \boldsymbol{A}\boldsymbol{v} \rangle = 0$，也就是 $\boldsymbol{\nu}$ 与 $\boldsymbol{W}$ 正交。而 $\boldsymbol{\nu} \in \boldsymbol{W}$，所以 $\boldsymbol{\nu} = \boldsymbol{0}$，矛盾。

第五步，构造乘子。令 $\boldsymbol{\lambda}^\star = \boldsymbol{\lambda}/\lambda_0$，$\boldsymbol{\nu}^\star = \boldsymbol{\nu}/\lambda_0$，除以 λ_0，上面第三步的不等式成为对所有 $\boldsymbol{x} \in \boldsymbol{D}$，

$$\mathcal{L}(\boldsymbol{x}, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) \geq f^\star.$$

对 $\boldsymbol{x}$ 取下确界，

$$q(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) \geq f^\star.$$

由弱对偶，

$$q(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) \leq d^\star \leq f^\star.$$

所以三者相等，并且这组乘子达到 $d^\star$。 ■

证明里 Slater 点只在第四步用到，这正是前面“排除竖直的纸”的严格写法。定理的结论并不包括原始最优点存在，这一点在第 18.4.3节用例子

18.1 下界的构造
18.2 弱对偶
18.3 凸共轭
18.4 强对偶
18.4.1 Slater 条件
18.4.2 共轭对偶的正则条件
18.4.3 间隙与达到的区别
18.5 最优性证书
18.6 本章小结

说明。Slater 点本身可行，所以 $f^\star < +\infty$，有限的假设只是排除 $f^\star = -\infty$；这时弱对偶迫使 $d^\star = -\infty$，对偶可行的乘子不存在，也就谈不上最优乘子。

如果某些 g_i 本身是仿射的，这些约束不必严格满足，只要 $g_i(\bar{\boldsymbol{x}}) \le 0$，其余要求不变。原因在于仿射约束的集合是多面体，分离时不会出现图 18.15(b) 那样切线竖直的边缘，这与线性规划不需要严格可行点的道理相同。证明需要用到多面体凸集的分离，篇幅较长，读者可查阅[1]。全部约束都仿射、目标线性时，这就是第 2章已经证明的强对偶。

[1] R. T. Rockafellar, *Convex Analysis*, Princeton University Press, 1970

18.4.2 共轭对偶的正则条件

复合问题 (18.25)没有不等式，不等式上的“严格可行”没有对应物，正则条件要换一种说法。回忆它的改写形式：变量 $(\boldsymbol{x}, \boldsymbol{z})$，有效定义域是 $\operatorname{dom} f \times \operatorname{dom} g$，约束是线性等式。Slater 条件要求的是存在满足等式、位于定义域相对内部的点。乘积集的仿射包是各因子仿射包的乘积，所以乘积集的相对内部等于各因子相对内部的乘积，这就翻译成了下面的条件。

定理 18.13 Fenchel 对偶的强对偶 设 $f : \mathbb{R}^n \to \mathbb{R} \cup \{+\infty\}$，$g : \mathbb{R}^p \to \mathbb{R} \cup \{+\infty\}$ 是适当、下半连续的凸函数，$\boldsymbol{A} \in \mathbb{R}^{p \times n}$。若存在 $\boldsymbol{x}$ 使

$$\boldsymbol{x} \in \operatorname{ri}(\operatorname{dom} f), \qquad \boldsymbol{A}\boldsymbol{x} \in \operatorname{ri}(\operatorname{dom} g), \tag{18.31}$$

且式 (18.25)的最优值 $F^\star$ 有限，则 $\sup_{\boldsymbol{\nu}} q(\boldsymbol{\nu}) = F^\star$，其中 q 由式 (18.26)给出，并且对偶最优值被达到。

证明 把定理 18.12用于改写形式，变量是 $(\boldsymbol{x}, \boldsymbol{z})$，目标是 $f(\boldsymbol{x}) + g(\boldsymbol{z})$，等式是 $\boldsymbol{A}\boldsymbol{x} - \boldsymbol{z} = \boldsymbol{0}$，没有不等式。若 $\boldsymbol{x}$ 满足式 (18.31)，则 $(\boldsymbol{x}, \boldsymbol{A}\boldsymbol{x})$ 在定义域的相对内部且满足等式，是 Slater 点。改写形式的对偶函数正是式 (18.26)。 ∎

证明中没有用到下半连续。这个假设保证 $f^{**} = f$ 和 $g^{**} = g$，使 q 对应的对偶问题再取一次对偶时能回到原问题，所以通常写在一起。定理保证的是两个最优值相等、对偶最优乘子存在，原始问题的最小点是否存在，要另外用强制性或紧性论证。

上一节的绝对值例中 $\operatorname{dom} f = \mathbb{R}^2$，$\operatorname{dom} g = \mathbb{R}$，两个定义域都是全空间，条件自动满足，所以那里的零间隙在算出结果之前就可以预知。

条件中的相对内部不是形式要求，看一个定义域只在边界上相遇的例子。取 $f(x) = -\sqrt{x}$（$x \ge 0$，其余为 $+\infty$），$g = \iota_{\{0\}}$，$A = 1$。此时要求 $x \in (0, \infty)$ 且 $x = 0$，式 (18.31)不成立。可行点只有 $x = 0$，所以 $F^\star = 0$。

18.1 下界的构造
18.2 弱对偶
18.3 凸共轭
18.4 强对偶
18.4.1 Slater 条件
18.4.2 共轭对偶的正则条件
18.4.3 间隙与达到的区别
18.5 最优性证书
18.6 本章小结

对偶一侧，$g^* = 0$。$\nu > 0$ 时 $f^*(-\nu) = \sup_{x\ge 0}\{-\nu x + \sqrt{x}\}$ 在 $\sqrt{x} = 1/(2\nu)$ 处达到，于是

$$f^*(-\nu) = \frac{1}{4\nu}, \qquad q(\nu) = -\frac{1}{4\nu}.$$

$\nu \le 0$ 时 $f^*(-\nu) = +\infty$。所以 $\sup q = 0 = F^\star$，零间隙仍然成立，但上确界取不到，对偶最优乘子不存在。

18.4.3 间隙与达到的区别

“强对偶成立”“原始最优点存在”“最优乘子存在”是三件不同的事。本小节用三个例子分别让其中一件出问题，表 18.2是它们的汇总。

第一个例子最小化 e^{-x}，约束 $-x \le 0$。Slater 点 $x = 1$ 存在，$f^\star = 0$ 有限，定理 18.12适用。第 18.1.1节已经算出 $q(0) = 0$，其余 $q(\lambda) = -\infty$，于是

$$d^\star = 0 = f^\star, \qquad \lambda^\star = 0.$$

零间隙成立，乘子达到，但没有 x 能使 $e^{-x} = 0$，原始最优值不达到。图 18.16(a) 是这个函数，它只在无穷远处靠近下确界。

第二个例子最小化 x，约束 $x^2 \le 0$。唯一的可行点是 $x = 0$，所以 $f^\star = 0$，原始最优点存在。Slater 条件不成立，因为 $x^2 < 0$ 无解。

对 $\lambda > 0$，$x + \lambda x^2$ 在 $x = -1/(2\lambda)$ 处最小，$\lambda = 0$ 时下确界为 $-\infty$。于是

$$q(\lambda) = -\frac{1}{4\lambda} \quad (\lambda > 0).$$

$\lambda \to +\infty$ 时 $q \to 0$，所以 $d^\star = 0 = f^\star$，零间隙成立，但没有有限的 λ 能达到。如图 18.16(b)，这正是图 18.15(b) 中切线竖直的代价。

这个例子还说明，第 17章在同一问题上看到的“最小点没有 KKT 乘子”，与“对偶最优值取不到”是同一件事的两面。

第三个例子的定义域是 $\boldsymbol{D} = \{\boldsymbol{x} \in \mathbb{R}^2 : x_2 > 0\}$，问题是

$$\min_{\boldsymbol{x}\in\boldsymbol{D}} e^{-x_1} \quad \text{s.t.} \quad \frac{x_1^2}{x_2} \le 0.$$

函数 x_1^2/x_2 在 $x_2 > 0$ 上是凸的，这可以由 Hessian 半正定验证，所以这是一个凸问题。约束迫使 $x_1 = 0$，于是 $f^\star = 1$，并在 $\{0\}\times(0,\infty)$ 上达到。

求对偶函数。对任意 $\lambda \ge 0$，内层函数 $e^{-x_1} + \lambda x_1^2/x_2$ 总是正的，所以 $q(\lambda) \ge 0$。沿曲线 $x_1 = s$，$x_2 = s^3$，令 $s \to +\infty$，有

$$e^{-s} + \frac{\lambda}{s} \to 0.$$

所以 $q(\lambda) = 0$ 对所有 $\lambda \ge 0$ 成立，$d^\star = 0$。

18.1 下界的构造
18.2 弱对偶
18.3 凸共轭
18.4 强对偶
18.5 最优性证书
18.5.1 零间隙与 KKT
18.5.2 Lagrange 鞍点
18.6 本章小结

两个最优值分别是 1 和 0，对偶间隙为 1。这说明凸性本身不能保证零间隙。Slater 条件在这里失败，因为 $x_1^2/x_2 < 0$ 无解。

图 18.16(c) 显示了联合集合的样子：最优值函数 v 在 $u = 0$ 处的值是 1，而 $u > 0$ 时只要让 x_1, x_2 都增大，就有 $x_1^2/x_2 \le u$，目标值可以任意接近 0，所以 $v(u) = 0$。v 在 $u = 0$ 处有一个跳跃，从下方托住 $\boldsymbol{A}$ 的直线最高只能到 0。

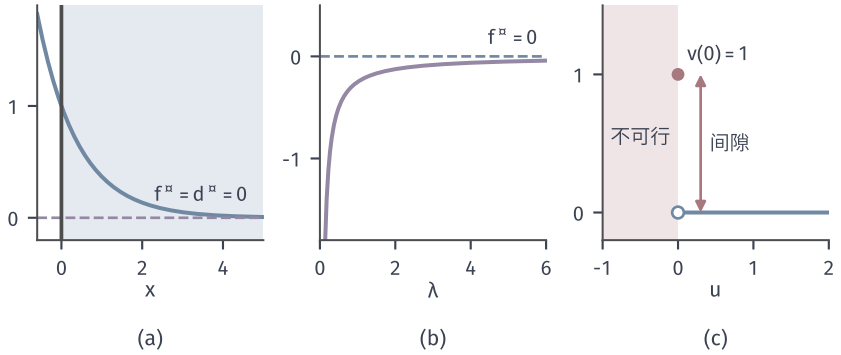


图 18.16 三种不同的情形。(a) 蓝线是 e^{-x}，浅蓝区域可行，下确界 0 不被取到，紫色虚线是 $d^\star$。(b) $\min x$，约束 $x^2 \le 0$ 的对偶函数 $q(\lambda) = -1/(4\lambda)$，向蓝色虚线 $f^\star = 0$ 靠近但取不到。(c) 第三个例子的最优值函数：浅红区域 $u < 0$ 不可行，红点是 $v(0) = 1$，$u > 0$ 时 $v(u) = 0$，空心点表示 $u = 0$ 时下极限，红色箭头是对偶间隙 1。

问题	Slater	$f^\star$	$d^\star$	原始达到	对偶达到
$\min e^{-x}$，$-x \le 0$	成立	0	0	否	是
$\min x$，$x^2 \le 0$	不成立	0	0	是	否
$\min e^{-x_1}$，$x_1^2/x_2 \le 0$	不成立	1	0	是	是

表 18.2 间隙与达到的三个例子。第三个例子全部乘子都是对偶最优的。

表中第二行和第三行都不满足 Slater 条件，结局却不同：一个零间隙，一个正间隙。所以 Slater 条件只是充分条件，不成立时要具体分析。

18.5 最优性证书

前面分别得到了下界、KKT 条件和强对偶。接下来要弄清：手上有一对原始—对偶候选，怎样判断它已经解决了原问题，这几种工具各自检验了什么？

先看一个不能只信对偶一侧的例子。设 $\boldsymbol{D} = [0, 1]$，

$$\min_{x \in [0,1]} \; -x \quad \text{s.t.} \quad x - \frac{1}{2} \le 0.$$

18.1 下界的构造
18.2 弱对偶
18.3 凸共轭
18.4 强对偶
18.5 最优性证书
18.5.1 零间隙与 KKT
18.5.2 Lagrange 鞍点
18.6 本章小结

目标要求 x 尽量大,约束限制 x 不超过 $1/2$,所以解是 $x^\star = 1/2, f^\star = -1/2$。Lagrange 函数对 x 是线性的，下确界在 $\boldsymbol{D}$ 的端点取得，比较 $x=0$ 和 $x=1$ 两处的值，得到

$$q(\lambda) = \min\Big\{-\frac{\lambda}{2},\ \frac{\lambda}{2} - 1\Big\}.$$

$\lambda^\star = 1$ 是这条折线的最高点，$q(1) = -1/2 = f^\star$，强对偶成立。一个只盯着对偶目标的算法到这里就停止了。但它手里的原变量是内层的最小点：$\lambda < 1$ 时是 $x=1$，$\lambda > 1$ 时是 $x=0$，如图 18.17(b) 所示。

$x=1$ 不可行，$x=0$ 可行但目标值是 0，比 $f^\star$ 差。$\lambda = 1$ 时内层的最小点是整个 $[0,1]$，$x^\star$ 只是其中一点，内层本身挑不出它。所以乘子停止改进不等于原问题解完了，求出的候选必须回到原问题上检验。

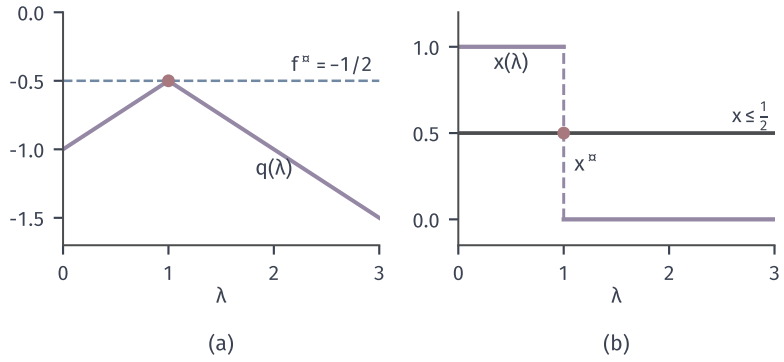


图 18.17 对偶最优不等于得到了原始解。(a) 紫线是折线 $q(\lambda)$，红点是对偶最优点 $\lambda^\star = 1$，蓝色虚线是 $f^\star$。(b) 紫线是内层最小点 $x(\lambda)$，它在 $\lambda = 1$ 处从 1 跳到 0，紫色虚线表示此时最小点是整个区间；深灰粗线是约束边界，红点是 $x^\star$，内层解不会自动落到它上面。

18.5.1 零间隙与 KKT

可以检验的证据是一对候选加上零间隙。第 17章的 KKT 条件是在候选点 $\boldsymbol{x}$ 处的四组关系：$\boldsymbol{x}$ 可行；$\boldsymbol{\lambda} \geq \mathbf{0}$；互补松弛 $\lambda_i g_i(\boldsymbol{x}) = 0$；以及 Lagrange 函数对 $\boldsymbol{x}$ 驻定，

$$\nabla f(\boldsymbol{x}) + \sum_i \lambda_i \nabla g_i(\boldsymbol{x}) + \sum_j \nu_j \nabla h_j(\boldsymbol{x}) = \mathbf{0}.$$

那里证明了，凸问题的 KKT 点是全局最小点。下面把这个结论与零间隙联系起来。

定理 18.14 零间隙与 KKT 考虑问题 (18.1)。

第一，设 $\boldsymbol{x}^\star$ 可行，$\boldsymbol{\lambda}^\star \geq \mathbf{0}$，且

$$f(\boldsymbol{x}^\star) = q(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star). \tag{18.32}$$

则 $\boldsymbol{x}^\star$ 原始全局最优，$(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 对偶最优，互补松弛成立，并且 $\boldsymbol{x}^\star$ 在 $\boldsymbol{D}$ 上全局最小化 $\mathcal{L}(\cdot, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$。若各函数在 $\boldsymbol{x}^\star$ 处可微且 $\boldsymbol{x}^\star \in \operatorname{int} \boldsymbol{D}$，则 $(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 满足 KKT 条件。

第二，设 $\boldsymbol{D}$ 是开凸集，f, g_i 在其上凸且可微，h_j 仿射，$(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 满足 KKT 条件。则式 (18.32)成立，原始、对偶两侧都最优。

证明 第一部分。由弱对偶，

$$f(\boldsymbol{x}^\star) = q(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) \leq d^\star \leq f^\star \leq f(\boldsymbol{x}^\star),$$

各处取等，所以两侧都最优。

再写一条链，由 q 的定义和可行性，

$$q(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) \leq \mathcal{L}(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) = f(\boldsymbol{x}^\star) + \sum_i \lambda_i^\star g_i(\boldsymbol{x}^\star) \leq f(\boldsymbol{x}^\star).$$

两端相等，所以两个不等号都取等。第二个不等号取等给出

$$\sum_i \lambda_i^\star g_i(\boldsymbol{x}^\star) = 0.$$

每一项非正，因此每一项都是零，这就是互补松弛。

第一个不等号取等，说明 $\mathcal{L}(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 等于它在 $\boldsymbol{D}$ 上的下确界，即 $\boldsymbol{x}^\star$ 是全局最小点。若 $\boldsymbol{x}^\star$ 是 $\boldsymbol{D}$ 的内点且函数可微，梯度为零就是驻定条件。

第二部分。$\lambda_i^\star \geq 0$ 且 h_j 仿射，所以 $\mathcal{L}(\cdot, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 在 $\boldsymbol{D}$ 上是凸函数，驻点就是全局最小点。于是由互补松弛和可行性，

$$q(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) = \mathcal{L}(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) = f(\boldsymbol{x}^\star).$$

再用第一部分即得结论。 ■

定理的第一部分不要求凸性，这是最通用的最优性证据，并且把 KKT 作为一个推论给出来。用预算例核对：$\boldsymbol{x}^\star = (3/2, 1/2)$ 可行，$\lambda^\star = 1/2$，由式 (18.8)有 $q(1/2) = 1/4 = f(\boldsymbol{x}^\star)$，所以这一对候选的最优性得到了证明，不需要知道解是怎样算出来的。

18.1 下界的构造
18.2 弱对偶
18.3 凸共轭
18.4 强对偶
18.5 最优性证书
18.5.1 零间隙与 KKT
18.5.2 Lagrange 鞍点
18.6 本章小结

反过来就要小心了。非凸问题的 Lagrange 驻定不代表内层全局最小，定理第二部分的凸性假设不能省略。看 $\min -x^2$，约束 $x-1\le 0$ 和 $-x-1\le 0$。图 18.18(a) 标出了三个 KKT 点：$x=0$（乘子全为零）和 $x=\pm 1$。

$x=0$ 的目标值是 0，它甚至是一个局部最大点，KKT 只把它列为候选。$x=1$ 是真正的全局最小点，由驻定条件 $-2+\lambda_1=0$ 得 $\lambda_1=2$，$\lambda_2=0$。此时

$$\mathcal{L}(x,2,0)=-x^2+2(x-1)=-(x-1)^2-1.$$

这条开口向下的抛物线在 $x=1$ 处是最大点，如图 18.18(b)。$q(2,0)=-\infty$，这一对 KKT 候选的候选间隙是 $+\infty$。

所以即便 $x=1$ 确实最优，这组乘子也给不出证书。换一种约束写法，结果又不同。把可行集写成 $x^2-1\le 0$，则

$$\mathcal{L}(x,\lambda)=(\lambda-1)x^2-\lambda,\qquad q(\lambda)=-\lambda\quad(\lambda\ge 1).$$

$\lambda=1$ 时 $q=-1=f^\star$，零间隙成立。可行集完全相同，对偶却依赖约束的写法，这也是非凸问题的一个特点。

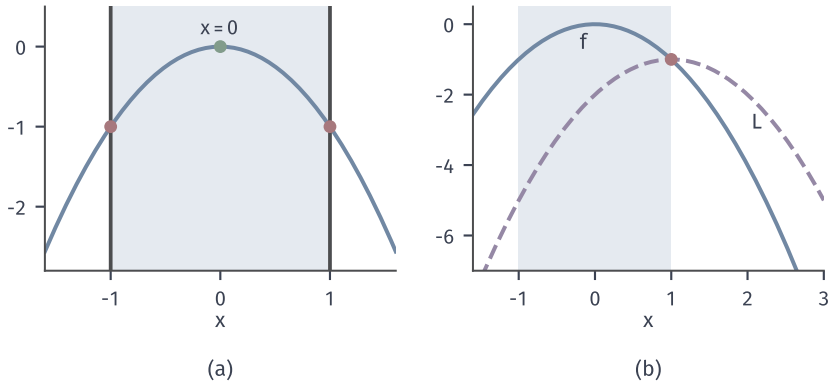


图 18.18　非凸问题的 KKT 点不等于零间隙候选。(a) $\min -x^2$，浅蓝区域是 $[-1,1]$，红点是全局最优点 $x=\pm 1$，绿点是 KKT 点 $x=0$，它是局部最大点。(b) 蓝线是 f，紫色虚线是 $\mathcal{L}(\cdot,2,0)=-(x-1)^2-1$，它在红点 $x=1$ 处驻定，但那里是最大点，$\mathcal{L}$ 没有下界。

18.5.2 Lagrange 鞍点

上面的证书也可以用一个不等式组写出，它把原始和对偶两个问题放在对称的位置上。关键的一步，是发现原问题本身也能用 $\mathcal{L}$ 写出来。固定 $\boldsymbol{x}\in\boldsymbol{D}$，对乘子取上确界：

$$\sup_{\boldsymbol{\lambda}\ge\mathbf{0},\,\boldsymbol{\nu}}\mathcal{L}(\boldsymbol{x},\boldsymbol{\lambda},\boldsymbol{\nu})=\begin{cases}f(\boldsymbol{x}), & \boldsymbol{x}\text{ 可行},\\ +\infty, & \boldsymbol{x}\text{ 不可行}.\end{cases}\tag{18.33}$$

理由是：若某条 $g_i(\boldsymbol{x}) > 0$，令 $\lambda_i \to +\infty$；若某条 $h_j(\boldsymbol{x}) \neq 0$，令 $\nu_j \to \pm\infty$，都趋于 $+\infty$。若 $\boldsymbol{x}$ 可行，$\lambda_i g_i \le 0$ 且 $\nu_j h_j = 0$，取 $\boldsymbol{\lambda} = \boldsymbol{0}$ 就达到上确界 $f(\boldsymbol{x})$。这就是开头说的“硬墙”：把价格抬到无穷大，就重新得到了硬约束。

所以原问题是 $\inf_{\boldsymbol{x}} \sup_{\boldsymbol{\lambda},\boldsymbol{\nu}} \mathcal{L}$，对偶问题是 $\sup_{\boldsymbol{\lambda},\boldsymbol{\nu}} \inf_{\boldsymbol{x}} \mathcal{L}$，两者只差取极值的次序，弱对偶正是一般的不等式 $\sup\inf \le \inf\sup$。图 18.19(b) 用一元例画出了式 (18.33)：$x = 0$ 可行，直线随 λ 下降，上确界在 $\lambda = 0$ 处取到 $f(0) = 2$；$x = 1.5$ 不可行，直线向上趋于无穷。

定义 18.15　Lagrange 鞍点　设 $\boldsymbol{x}^\star \in \boldsymbol{D}$，$\boldsymbol{\lambda}^\star \ge \boldsymbol{0}$。若对所有 $\boldsymbol{x} \in \boldsymbol{D}$、$\boldsymbol{\lambda} \ge \boldsymbol{0}$、$\boldsymbol{\nu}$ 都有

$$\mathcal{L}(\boldsymbol{x}^\star, \boldsymbol{\lambda}, \boldsymbol{\nu}) \le \mathcal{L}(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) \le \mathcal{L}(\boldsymbol{x}, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star), \tag{18.34}$$

就称 $(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 是Lagrange 鞍点（Lagrangian saddle point）。

式 (18.34)的右半边是全局最小，不是局部驻定，这是它与 KKT 的关键区别。图 18.19(a) 是一元例中 $\mathcal{L}(x,\lambda)$ 的等高线，$(1,1)$ 是鞍点。沿绿色虚线（固定 $\lambda = 1$）$\mathcal{L}$ 在 $x = 1$ 处最小，见图 18.19(c)；沿紫色虚线（固定 $x = 1$）$\mathcal{L}$ 恒为 $\frac{1}{2}$，这时左半边取等。

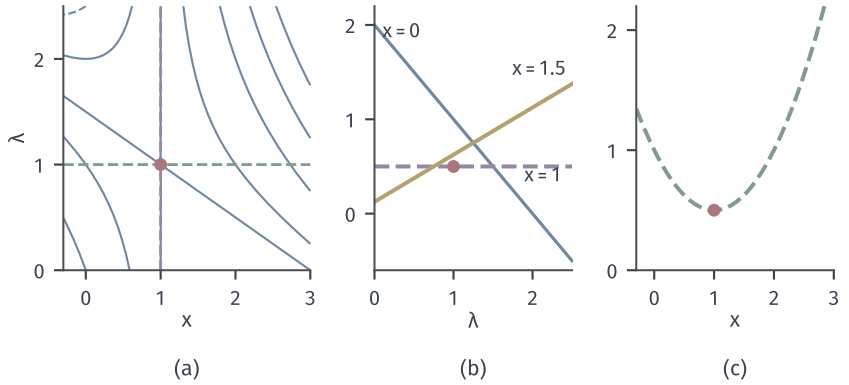


图 18.19　一元例的 Lagrange 鞍点。(a) 蓝线是 $\mathcal{L}(x,\lambda) = \frac{1}{2}(x-2)^2 + \lambda(x-1)$ 的等高线，红点是鞍点 $(1,1)$，绿色虚线固定 $\lambda = 1$，紫色虚线固定 $x = 1$。(b) 固定 x 时 $\mathcal{L}$ 关于 λ 的直线：蓝线 $x = 0$ 可行，黄线 $x = 1.5$ 不可行，紫色虚线是 $x = 1$。(c) 固定 $\lambda = 1$ 时关于 x 的抛物线，红点是最小点。

定理 18.16　鞍点等价于两侧达到且零间隙　$(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 是 Lagrange 鞍点，当且仅当 $\boldsymbol{x}^\star$ 是原始最优点，$(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 是对偶最优乘子，并且式 (18.32)成立。此结论不要求问题凸。

证明 必要性。记鞍点处的 Lagrange 函数值为 $\mathcal{L}^\star$。式 (18.34)左半边说明 $\mathcal{L}(\boldsymbol{x}^\star, \cdot, \cdot)$ 对乘子有上界，由式 (18.33)，$\boldsymbol{x}^\star$ 可行，并且上确界 $f(\boldsymbol{x}^\star) \leq \mathcal{L}^\star$。

由 $\boldsymbol{\lambda}^\star \geq \mathbf{0}$ 和可行性，又有 $\mathcal{L}^\star \leq f(\boldsymbol{x}^\star)$，所以

$$\mathcal{L}^\star = f(\boldsymbol{x}^\star).$$

式 (18.34)右半边说明 $\boldsymbol{x}^\star$ 是 $\mathcal{L}(\cdot, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 在 $\boldsymbol{D}$ 上的全局最小点，所以

$$q(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) = \mathcal{L}^\star = f(\boldsymbol{x}^\star).$$

由定理 18.14第一部分，两侧都最优。

充分性。设 $\boldsymbol{x}^\star$ 可行，$\boldsymbol{\lambda}^\star \geq \mathbf{0}$，且式 (18.32)成立。由定理 18.14第一部分，互补松弛成立，所以 $\mathcal{L}^\star = f(\boldsymbol{x}^\star)$，且 $\boldsymbol{x}^\star$ 全局最小化 $\mathcal{L}(\cdot, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$，这是右半边。对任意 $\boldsymbol{\lambda} \geq \mathbf{0}$ 和 $\boldsymbol{\nu}$，由可行性，

$$\mathcal{L}(\boldsymbol{x}^\star, \boldsymbol{\lambda}, \boldsymbol{\nu}) = f(\boldsymbol{x}^\star) + \sum_i \lambda_i g_i(\boldsymbol{x}^\star) \leq f(\boldsymbol{x}^\star) = \mathcal{L}^\star,$$

这是左半边。 ■

由定理 18.16，鞍点存在需要两个最优值都达到并且相等，这比强对偶强。第 18.4.3节前两个例子零间隙，却都没有鞍点，因为其中一侧没有达到。

把驻定当成鞍点是常见的错误。上一小节的 $(1, 2, 0)$ 使 $\nabla_x \mathcal{L} = 0$，但 $x = 1$ 是 $\mathcal{L}$ 的最大点，这组点满足 KKT，却不满足式 (18.34)的右半边。一般的极小极大问题中交换取极值次序的条件，由第 27章专门研究，这里的 $\mathcal{L}$ 对乘子是线性的，是其中结构较简单的一类。

图 18.20和表 18.3把这一节的关系放在一起。中间的结论只有一个：一对候选，两边都全局最优，且目标值相等。

18.1　下界的构造
18.2　弱对偶
18.3　凸共轭
18.4　强对偶
18.5　最优性证书
18.6　本章小结

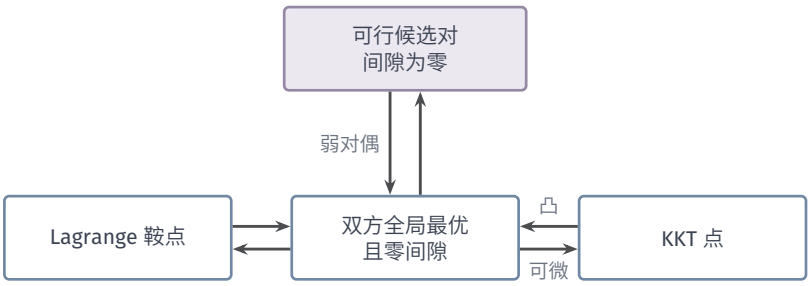


图 18.20　几种最优性证据的关系。零间隙的可行候选对与“双方全局最优且零间隙”等价，后者与 Lagrange 鞍点等价，这三者都不要求凸性；从 KKT 点推出中间结论需要凸性，从中间结论推出 KKT 点需要在内点处可微。

证据	要检查什么	能断言什么
KKT	可行、符号、互补、驻定	凸时才全局最优
候选间隙	可行、合法乘子、可信的 q	次优性不超过间隙
零间隙	同上，且间隙为零	两侧全局最优
鞍点	式 (18.34)，右半为全局最小	与零间隙候选对等价

表 18.3　几种最优性证据的比较。除 KKT 外，其余三种证据都不要求问题凸。

18.6　本章小结

本章开头的问题是，手里有一个可行点，怎样知道它离最优还差多少。回答是对偶函数：固定一组合法乘子，对原变量在整个定义域上取下确界，得到的数就是最优值的下界。这个下界只用了下确界的定义和符号，所以弱对偶不需要凸性、可微性和约束资格。对偶函数总是凹的，但计算它的每个值都要做一次内层全局最小化。

一对候选给出的误差证书 $f(\hat{\boldsymbol{x}}) - q(\boldsymbol{\lambda}, \boldsymbol{\nu})$ 有三个前提：原始可行，乘子合法，q 算得可信。内层近似得到的值在真正的下界上方，必须扣除经过证明的误差，才能写进证书。

凸共轭把“函数加线性项取下确界”单独提取出来，二次函数、范数、约束指标函数的共轭分别对应二次项、对偶范数球和支撑函数，由此可以直接写出线性约束问题和复合问题的对偶形式。共轭能够重建适当、下半连续的凸函数，但这一点与某个具体问题的零间隙是两回事。

最好的下界是否等于最优值，取决于正则条件。Slater 条件和复合问题的相对内部条件都排除了竖直的支撑超平面，保证零间隙和对偶最优乘子存在，却不保证原始最优点存在。凸性本身不能保证零间隙，零间隙也不保证两侧都达到。

实际使用时，能够核对的证据是一对候选加上间隙。零间隙的候选对同时给出两侧的全局最优性，等价于 Lagrange 鞍点，这些结论不要求凸性；

KKT 点在凸问题中才等价于它们。乘子如何解释参数的变化，由第 19章讨论；怎样在算法中实际更新乘子，由第 22章讨论。

19.1 含参问题
19.2 最优值的变化
19.3 最优解的变化
19.4 分支变化
19.5 导数的计算与核验
19.6 本章小结

第 19 章

参数敏感性

一笔预算要分给两种投入。预算从 2 增加到 2.1，最优的损失能下降多少？理想配置改变一点，最优配置又往哪里移动？这些问题里，变的不是求解过程，而是问题本身。

把新问题重新解一遍当然可以得到答案，但它只回答一个具体的数。我们还想知道：多一单位预算值多少钱，这个价钱在多大范围内可信，几个参数同时变化时不重新求解能否估计结果，以及什么时候这样的估计根本不成立。

本章区分两个输出。最优值是一个数，它的变化可以由对偶乘子给出对任意大小扰动都成立的下界，也可以由包络关系给出局部导数。最优解是一个向量，它的移动要把最优性条件看成方程，用隐函数定理求导，因而需要更强的条件。

第 19.1节先说清参数变化时比较的是什么对象。第 19.2节研究最优值，第 19.3节研究最优解，全章用同一个预算二次问题来核对公式。局部导数并不总是存在，第 19.4节用可以手算的例子拆开三种失效的原因。第 19.5节讨论怎样计算这些导数，又怎样检验算出的导数可信。

19.1 含参问题

参数变化之后，“解的变化”到底指什么？本节要先回答这个问题。参数一变，问题可能没有解，也可能有许多解，所以必须先把比较的对象定义清楚。

贯穿全章的预算二次例　沿用第 17章的预算分配。两种投入的数量是 x_1、x_2，它们非负，总量不超过预算 τ。理想配置是 $(2,1)$，偏离理想配置按平方计算损失。于是得到问题

$$\min_{x\in\mathbb{R}^2}\ \frac{1}{2}(x_1-2)^2+\frac{1}{2}(x_2-1)^2 \quad \text{s.t.} \quad x_1+x_2\le\tau,\ x_1\ge 0,\ x_2\ge 0. \tag{19.1}$$

为了和一般记号对应，把三条约束写成 $g_1 = x_1 + x_2 - \tau$、$g_2 = -x_1$、$g_3 = -x_2$，都要求不大于零，相应的乘子是 $\lambda_1, \lambda_2, \lambda_3$。

这个问题有清楚的几何图景。目标的等高线是以理想点 $\boldsymbol{c} = (2, 1)$ 为圆心的同心圆，所以最优解就是可行三角形里离 $\boldsymbol{c}$ 最近的点。预算线像一堵可以平移的墙，τ 增大时墙向外退，三角形变大。

图 19.1画出三个预算水平。$\tau = 4$ 时墙退得很远，碗底 $(2, 1)$ 本身可行，没有约束起作用。$\tau = 2$ 时碗底被挡在墙外，解落在预算线上的 $(3/2, 1/2)$。$\tau = 0.5$ 时三角形很小，解被挤到角点 $(0.5, 0)$，预算和 $x_2 \geq 0$ 同时起作用。

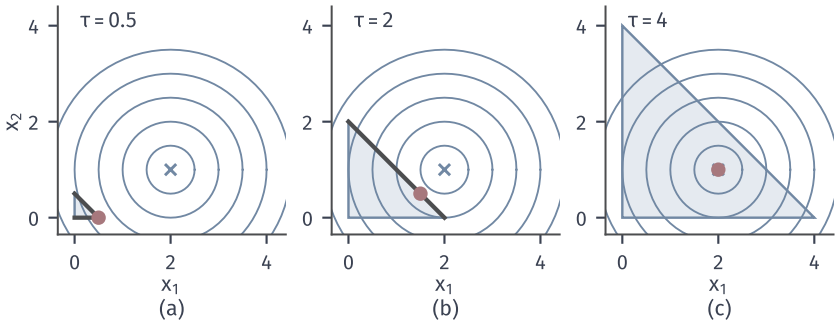


图 19.1　预算二次例 (19.1)在三个预算下的情形。浅蓝三角形是可行集，蓝色同心圆是目标等高线，蓝色叉是理想点 $(2, 1)$，红点是最优解，深灰粗线是起作用的约束。(a) $\tau = 0.5$，预算和 $x_2 \geq 0$ 都起作用。(b) $\tau = 2$，只有预算起作用。(c) $\tau = 4$，没有约束起作用。

变量与参数　式 (19.1)里有两类量。$\boldsymbol{x}$ 由优化决定，τ 由外部给定，求解时保持不变。前者是我们的选择，后者是我们所处的环境。同一个量算变量还是参数，取决于建模时想回答什么：若预算也可以选择，它就应该成为变量。

把环境写成参数向量 θ，每个 θ 确定一个优化问题，全体构成一族问题。研究这族问题，需要两个输出对象。

定义 19.1　含参问题、最优值函数与解映射　设 $\Theta \subseteq \mathbb{R}^q$ 是参数集合。对每个 $\theta \in \Theta$，给定可行集 $C(\theta) \subseteq \mathbb{R}^n$ 和目标 $f(\cdot, \theta)$，称

$$\min_{\boldsymbol{x} \in C(\theta)} f(\boldsymbol{x}, \theta) \tag{19.2}$$

为含参问题（parametric problem）。函数

$$V(\theta) = \inf_{\boldsymbol{x} \in C(\theta)} f(\boldsymbol{x}, \theta) \tag{19.3}$$

称为**最优值函数**（value function），并约定空集上的下确界为 $+\infty$。把每个参数对应到最优解集合的映射

$$\boldsymbol{S}(\theta) = \{\boldsymbol{x} \in \boldsymbol{C}(\theta) : f(\boldsymbol{x}, \theta) = V(\theta)\} \tag{19.4}$$

称为**解映射**（solution map）。

V 和 $\boldsymbol{S}$ 的性格很不一样。$V(\theta)$ 总是一个确定的量，只是可能取 $\pm\infty$。$\boldsymbol{S}(\theta)$ 是一个集合，可能是空集，可能只有一个点，也可能有无穷多个点。对预算例，$\tau < 0$ 时可行集是空集，所以 $V(\tau) = +\infty$，$\boldsymbol{S}(\tau) = \varnothing$。$\tau \geq 0$ 时目标强凸、可行集紧，$\boldsymbol{S}(\tau)$ 恰有一个点。

参数改变可能使问题失去解　除了不可行，参数改变还可能让最小值取不到。下面的一族问题定义在整条实轴上：

$$\min_{x \in \mathbb{R}} \; f(x, \theta) = e^{x} - \theta x.$$

图 19.2画出三种情况，下面逐个计算。

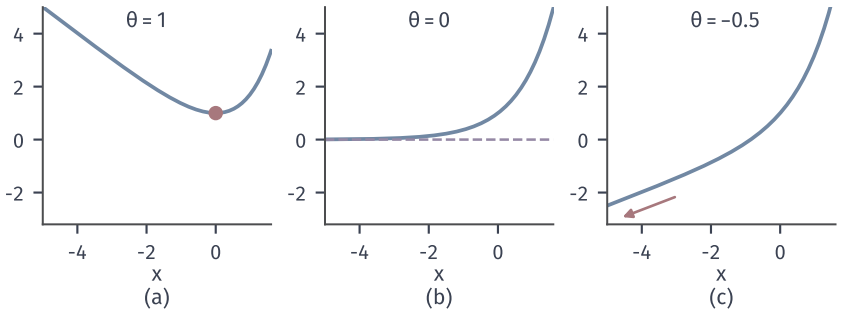


图 19.2　同一族目标 $f(x, \theta) = e^{x} - \theta x$ 在三个参数下的结果。(a) $\theta = 1$，最小值 1 在红点 $x = 0$ 取得。(b) $\theta = 0$，下确界 0（紫色虚线）有限但取不到。(c) $\theta = -0.5$，红色箭头表示目标沿 $x \to -\infty$ 无下界。

$\theta > 0$ 时，令导数 $e^{x} - \theta$ 为零，得到唯一的驻点 $x = \ln\theta$。二阶导数 e^{x} 为正，所以它是全局极小点，并且

$$V(\theta) = \theta - \theta\ln\theta, \qquad \boldsymbol{S}(\theta) = \{\ln\theta\}.$$

$\theta = 0$ 时目标是 e^{x}，它的下确界是 0，但没有点取得这个值，所以 $V(0) = 0$ 而 $\boldsymbol{S}(0) = \varnothing$。$\theta < 0$ 时，$x \to -\infty$ 使 $-\theta x = |\theta| x \to -\infty$，而 $e^{x} \to 0$，所以 $V(\theta) = -\infty$。

这族问题还显示出值与解的差别。$\theta \downarrow 0$ 时，$V(\theta) = \theta - \theta \ln \theta \to 0 = V(0)$，值的变化是连续的。解却是 $\ln \theta \to -\infty$，一路跑向无穷远。讨论变化之前，必须先确认所研究的 θ 处解存在，并说明比较的是值还是解。

有多个解时要说清跟踪谁 考虑一个有两个山谷的目标：

$$f(x, \theta) = (x^2 - 1)^2 + \theta x. \tag{19.5}$$

$\theta = 0$ 时两个谷底 $x = \pm 1$ 同样低，$\boldsymbol{S}(0) = \{-1, 1\}$。$\theta$ 不为零时，θx 这一项把地面倾斜，一个谷底升高，另一个降低。“最优解对 θ 的导数”这句话在 $\theta = 0$ 处没有明确含义，因为不知道说的是哪一个解。

这时有两种办法把问题说清楚。一种是跟踪一条**局部极小分支**（local minimizer branch），即在 θ_0 的邻域上定义的映射 $\boldsymbol{x}(\theta)$，使每个 $\boldsymbol{x}(\theta)$ 都是相应问题的局部极小点，并且随 θ 连续变化。另一种是约定**选解规则**（selection rule），例如总取最优解中范数最小的一个。

沿分支的目标值记作

$$v(\theta) = f(\boldsymbol{x}(\theta), \theta). \tag{19.6}$$

小写的 v 是某条分支上的值，大写的 V 是全局最优值。分支上的点都可行，所以 $v(\theta) \geq V(\theta)$，只有分支恰好全局最优时才取等号。

图 19.3展示了这种区别。(b) 中两条绿色虚线是两个谷底的位置，它们各自光滑。红色实线是全局最优解，它在 $\theta = 0$ 处从上面一条跳到下面一条。(c) 中分支的值光滑地穿过 $\theta = 0$，全局最优值是两者中较小的那个，在 $\theta = 0$ 处有折角。例如沿右侧谷底的分支在 $\theta > 0$ 时仍然是局部极小，但它的值已经高于全局最优值，不能称为“最优值”。

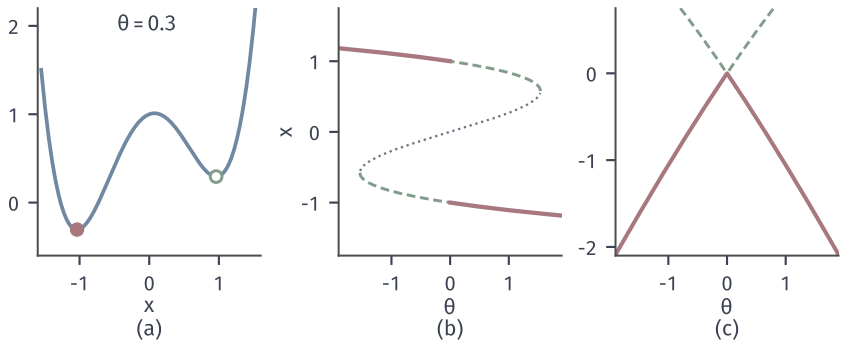


图 19.3 双谷目标 (19.5)的分支与全局解。(a) $\theta = 0.3$ 时的目标，红点是全局最小点，绿色空心点是另一个局部极小点。(b) 驻点随 θ 的变化：绿色虚线是局部极小分支，灰色点线是局部极大分支，红色实线是全局最优解。(c) 绿色虚线是两条分支上的目标值，红色实线是全局最优值。

19.1 含参问题
19.2 最优值的变化
19.2.1 约束右端的全局变化界
19.2.2 乘子的边际解释
19.2.3 目标参数的包络关系
19.2.4 一般含参约束
19.3 最优解的变化
19.4 分支变化
19.5 导数的计算与核验
19.6 本章小结

图 19.4汇总这些对象的关系。本章每个结论都会说明针对哪一个对象：是全局的 V，还是某条分支上的 v；是整个解集合 $\boldsymbol{S}$，还是分支 $\boldsymbol{x}(\boldsymbol{\theta})$。

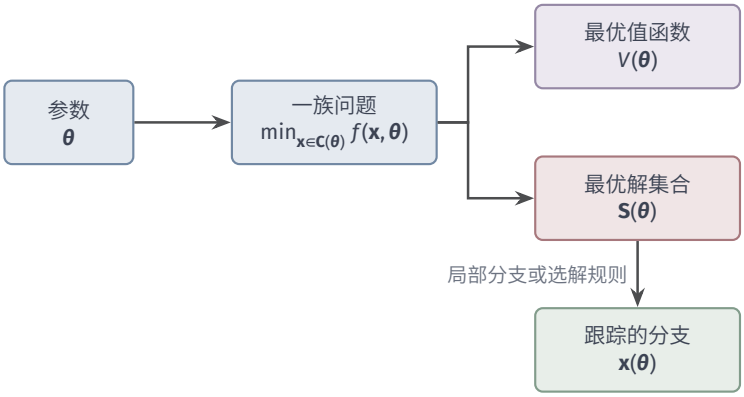


图 19.4　含参问题的三个输出对象。参数确定一个优化问题，问题确定最优值函数和最优解集合。解集合可能为空或含多个点，只有通过局部分支或选解规则，才得到一个随参数变化的点。

19.2 最优值的变化

参数变了以后，最优值变化多少？本节研究这个问题。先让约束的右端变化，乘子会给出一个对任意大小的扰动都成立的下界；再让目标和约束显含一般的参数，这时得到的是局部导数。“下界的斜率”“实际的导数”“方向导数”是三个不同的量，下面逐个说明它们各自成立的条件。

19.2.1 约束右端的全局变化界

扰动右端　对一般约束问题，在每条约束的右端加上扰动，定义

$$V(\boldsymbol{u},\boldsymbol{v})=\inf\{f(\boldsymbol{x}):\ g_i(\boldsymbol{x})\le u_i,\ h_j(\boldsymbol{x})=v_j,\ \forall i,j\}. \tag{19.7}$$

这里 $\boldsymbol{u}\in\mathbb{R}^m$，$\boldsymbol{v}\in\mathbb{R}^p$，不可行时 $V=+\infty$。基准问题的最优值是 $f^\star=V(\mathbf{0},\mathbf{0})$。$u_i>0$ 把第 i 条不等式放宽，$u_i<0$ 把它收紧。

按旧价格结算　第 18章的 Lagrange 函数是

$$\mathcal{L}(\boldsymbol{x},\boldsymbol{\lambda},\boldsymbol{\nu})=f(\boldsymbol{x})+\sum_{i=1}^{m}\lambda_i g_i(\boldsymbol{x})+\sum_{j=1}^{p}\nu_j h_j(\boldsymbol{x}),$$

对偶函数是

$$q(\boldsymbol{\lambda},\boldsymbol{\nu})=\inf_{\boldsymbol{x}}\mathcal{L}(\boldsymbol{x},\boldsymbol{\lambda},\boldsymbol{\nu}).$$

弱对偶说 $\boldsymbol{\lambda}\ge\mathbf{0}$ 时 $q(\boldsymbol{\lambda},\boldsymbol{\nu})\le f^\star$，强对偶且乘子达到则说存在 $(\boldsymbol{\lambda}^\star,\boldsymbol{\nu}^\star)$，使 $q(\boldsymbol{\lambda}^\star,\boldsymbol{\nu}^\star)=f^\star$。

可以把乘子想成一张事先定好的价格表：用 $g_i(\boldsymbol{x})$ 这么多资源，就按 $\lambda_i^\star$ 的单价结算。强对偶达到的意思是，在这张价格表下，每一个点 $\boldsymbol{x}$ 的结算额 $\mathcal{L}(\boldsymbol{x},\boldsymbol{\lambda}^\star,\boldsymbol{\nu}^\star)$ 都不低于 $f^\star$。若右端变了，新问题的可行点仍然要按这张旧价格表结算，结算额的下限不变，由此就得到新最优值的下界。

定理 19.2　最优值的全局下界　设基准问题的最优值 $f^\star$ 有限，存在 $\boldsymbol{\lambda}^\star \geq \boldsymbol{0}$ 与 $\boldsymbol{\nu}^\star$，使 $q(\boldsymbol{\lambda}^\star,\boldsymbol{\nu}^\star) = f^\star$。则对所有 $(\boldsymbol{u},\boldsymbol{v}) \in \mathbb{R}^m \times \mathbb{R}^p$，

$$V(\boldsymbol{u},\boldsymbol{v}) \geq f^\star - \langle \boldsymbol{\lambda}^\star, \boldsymbol{u}\rangle - \langle \boldsymbol{\nu}^\star, \boldsymbol{v}\rangle. \tag{19.8}$$

证明　若扰动问题不可行，左端是 $+\infty$，结论成立。否则任取扰动问题的可行点 $\boldsymbol{x}$。由 q 的定义，

$$f^\star = q(\boldsymbol{\lambda}^\star,\boldsymbol{\nu}^\star) \leq \mathcal{L}(\boldsymbol{x},\boldsymbol{\lambda}^\star,\boldsymbol{\nu}^\star).$$

把 Lagrange 函数展开。由 $\lambda_i^\star \geq 0$ 和 $g_i(\boldsymbol{x}) \leq u_i$，第 i 个不等式项不超过 $\lambda_i^\star u_i$。由 $h_j(\boldsymbol{x}) = v_j$，等式项正好等于 $\nu_j^\star v_j$。于是

$$f^\star \leq f(\boldsymbol{x}) + \langle \boldsymbol{\lambda}^\star, \boldsymbol{u}\rangle + \langle \boldsymbol{\nu}^\star, \boldsymbol{v}\rangle.$$

移项后对所有可行的 $\boldsymbol{x}$ 取下确界，就得到式 (19.8)。 ■

式 (19.8)的右端是 $(\boldsymbol{u},\boldsymbol{v})$ 的仿射函数，它在原点与 V 相等，在其他地方不超过 V。第 i 条不等式方向上，下界的斜率是 $-\lambda_i^\star$，负号来自“右端增大意味着约束放宽”。放宽 $u_i > 0$ 时，最优值至多下降 $\lambda_i^\star u_i$。收紧 $u_i < 0$ 时，最优值至少上升 $\lambda_i^\star |u_i|$。

条件各起什么作用　定理没有要求问题是凸的，也没有要求函数可微，证明里只用了不等式。它也不要求扰动后的解和基准解有相同的活动约束，甚至不要求解存在。所以这是一个全局结论，对很大的扰动同样成立，只是方向是单侧的。

定理还有一个推论：在这些条件下，任何右端扰动都不会使问题变得无下界，因为式 (19.8)的右端总是有限的。

预算例的验证　取基准预算 $\tau = 2$，令 $u = \tau - 2$，只扰动第一条约束。基准解是 $\boldsymbol{x}^\star = (3/2, 1/2)$，后两条约束不起作用。乘子取 $\boldsymbol{\lambda}^\star = (1/2, 0, 0)$，此时 Lagrange 函数是

$$\mathcal{L}(\boldsymbol{x},\boldsymbol{\lambda}^\star) = \frac{1}{2}(x_1 - 2)^2 + \frac{1}{2}(x_2 - 1)^2 + \frac{1}{2}(x_1 + x_2 - 2).$$

这是关于 $\boldsymbol{x}$ 的强凸二次函数。令梯度为零，得到 $x_1 - 2 + \tfrac{1}{2} = 0$ 与 $x_2 - 1 + \tfrac{1}{2} = 0$，极小点恰好是 $(3/2, 1/2)$。把它代入，因为 $x_1 + x_2 - 2 = 0$，所以

$$q(\boldsymbol{\lambda}^\star) = \frac{1}{2}\cdot\frac{1}{4} + \frac{1}{2}\cdot\frac{1}{4} = \frac{1}{4} = f^\star.$$

零间隙得到验证，强对偶和乘子达到都成立。式 (19.8)于是给出：对所有 τ，

$$V(\tau) \geq \frac{1}{4} - \frac{1}{2}(\tau - 2). \tag{19.9}$$

下面在三个预算上核对。对 $\tau = 2.1$，解是 $(1.55, 0.55)$；对 $\tau = 0.5$，解是 $(0.5, 0)$；对 $\tau = 4$，解是 $(2, 1)$。三处的真实最优值和下界分别是

$$V(2.1) = 0.2025 \geq 0.2, \qquad V(0.5) = 1.625 \geq 1, \qquad V(4) = 0 \geq -0.75.$$

预算从 2 增加到 2.1 时，最优值实际下降 0.0475，下界说它至多下降 0.05。注意 $\tau = 0.5$ 时活动约束已经和基准解不同，$\tau = 4$ 时预算根本不起作用，下界依然正确。图 19.5画出整条曲线，紫色直线始终在蓝色曲线下方。

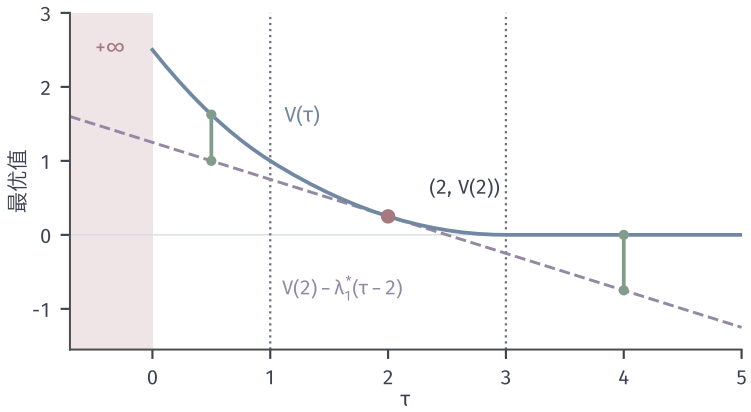


图 19.5 预算例的最优值函数（蓝线）和由 $\tau = 2$ 处乘子 $\lambda_1^\star = 1/2$ 给出的下界（紫色虚线）。红点是基准点，绿色线段是 $\tau = 0.5$ 和 $\tau = 4$ 处下界的余量，灰色点线标出活动约束改变的 $\tau = 1, 3$。红色区域 $\tau < 0$ 不可行，$V = +\infty$。

去掉强对偶会怎样 强对偶达到这个条件不能换成“存在 KKT 乘子”。考虑非凸问题

$$\min_{x \in \mathbb{R}} \; -x^2 \quad \text{s.t.} \quad x - 1 \leq u, \; -x - 1 \leq 0.$$

基准问题 $u = 0$ 的可行集是 $[-1, 1]$，$f^\star = -1$，在 $x = \pm 1$ 取得。

在 $x = 1$ 处，平稳条件 $-2x + \lambda_1 = 0$ 给出 KKT 乘子 $\lambda_1 = 2$，第二条约束不起作用，$\lambda_2 = 0$。如果照搬式 (19.8)，会得到 $V(u) \geq -1 - 2u$。

19.1 含参问题
19.2 最优值的变化
19.2.1 约束右端的全局变化界
19.2.2 乘子的边际解释
19.2.3 目标参数的包络关系
19.2.4 一般含参约束
19.3 最优解的变化
19.4 分支变化
19.5 导数的计算与核验
19.6 本章小结

直接计算最优值。$u > 0$ 时可行集是 $[-1, 1+u]$，最小点在 $x = 1+u$。$-2 \le u \le 0$ 时，可行集右端点的绝对值不超过 1，最小点在 $x = -1$。所以

$$V(u) = \begin{cases} -1, & -2 \le u \le 0, \\ -(1+u)^2, & u > 0. \end{cases}$$

$u > 0$ 时，

$$V(u) - (-1 - 2u) = -u^2 < 0,$$

下界不成立，见图 19.6。原因是这个问题的对偶函数对任何乘子都是 $-\infty$，强对偶不成立。KKT 乘子只承载局部信息，全局下界必须由对偶最优的乘子给出。

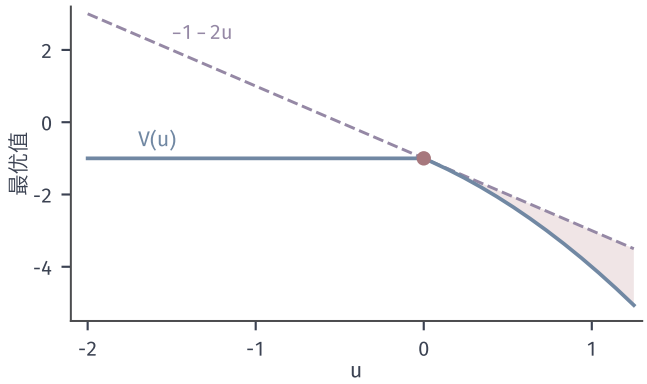


图 19.6 KKT 乘子不给出全局下界的例子。蓝线是 $\min -x^2$，$x - 1 \le u$，$x \ge -1$ 的最优值 $V(u)$，紫色虚线是用 $x = 1$ 处 KKT 乘子 2 写出的直线 $-1 - 2u$，红色区域表示 $u > 0$ 时直线高于 V。

非凸并不一定导致失败。对问题 $\min -x^2$, $x^2 - 1 \le u$, 取 $\lambda = 1$, Lagrange 函数恒等于 -1，所以 $q(1) = -1 = f^\star$。此时 $V(u) = -1 - u$（$u \ge -1$），下界恰好取等号。起决定作用的是零间隙，而不是凸性。

19.2.2 乘子的边际解释

下界只说明 V 不低于一条直线。什么时候这条直线就是 V 的切线，乘子就是最优值的真实变化率？本小节回答这个问题。

直线贴着曲线时 一条直线处处不高于曲线，又在基准点与曲线相交。如果曲线在该点光滑，直线就没有选择，只能是切线。这正是图 19.5中红点处的情形。把这个几何观察写成定理：

定理 19.3 乘子是边际变化率 在定理 19.2的条件下，进一步设 V 在 $(\mathbf{0},\mathbf{0})$ 附近有限且在 $(\mathbf{0},\mathbf{0})$ 可微，则

$$\frac{\partial V}{\partial u_i}(\mathbf{0},\mathbf{0}) = -\lambda_i^\star, \qquad \frac{\partial V}{\partial v_j}(\mathbf{0},\mathbf{0}) = -\nu_j^\star. \tag{19.10}$$

证明 定义函数

$$\varphi(\boldsymbol{u},\boldsymbol{v}) = V(\boldsymbol{u},\boldsymbol{v}) - f^\star + \langle \boldsymbol{\lambda}^\star, \boldsymbol{u}\rangle + \langle \boldsymbol{\nu}^\star, \boldsymbol{v}\rangle.$$

式 (19.8)说明 $\varphi \geq 0$，而 $\varphi(\mathbf{0},\mathbf{0}) = 0$，所以原点是 φ 的极小点。原点是定义域的内点，φ 在原点可微，它的梯度必须为零。写出这个梯度的各个分量，就是式 (19.10)。 ■

定理同时说明，只要 V 在基准点可微，满足条件的乘子就是唯一的，因为它们都等于 V 的梯度的相反数。

几何含义 在预算例中，$-\nabla f(\boldsymbol{x}^\star) = \lambda_1^\star(1,1)$ 垂直于预算线。图 19.7中，预算增加 $\Delta\tau$ 时，预算线沿法向平移 $\Delta\tau/\sqrt{2}$。目标沿法向的变化率是

$$\|\nabla f(\boldsymbol{x}^\star)\|_2 = \lambda_1^\star\sqrt{2}.$$

两者相乘，目标的一阶下降量是 $\lambda_1^\star\Delta\tau$，这就是乘子作为影子价格的含义：多一单位预算大约值 $\lambda_1^\star$。没有起作用的约束乘子为零，放宽它们一阶没有价值。

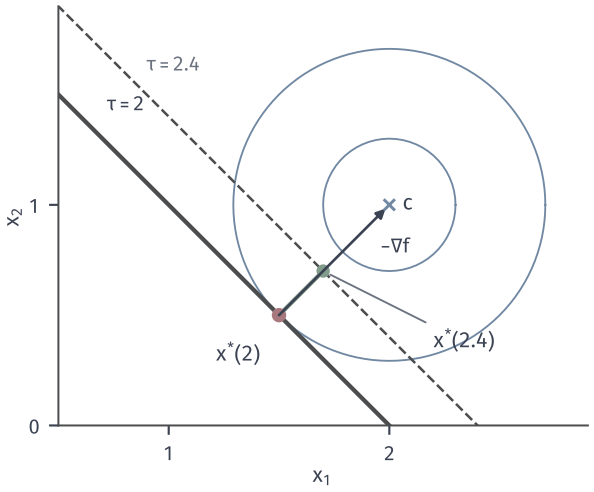


图 19.7 预算线平移与乘子。深灰实线是 $\tau = 2$ 的预算线，虚线是 $\tau = 2.4$ 的预算线，蓝色圆是目标等高线。黑色箭头是 $-\nabla f(\boldsymbol{x}^\star) = \lambda_1^\star(1,1)$，从红点指向理想点 $\boldsymbol{c}$。绿色线段是最优解的移动。

核对数值。$1<\tau<3$ 时，$V(\tau)=(3-\tau)^2/4$，这个公式将在第 19.4.1节推出。于是 $V'(2)=-1/2=-\lambda_1^\star$。取 $\Delta\tau=0.4$，一阶估计是 $0.25-0.2=0.05$，真实值 $V(2.4)=0.09$。一阶估计恰好等于式 (19.9)的下界，真实值在它上方。

值函数不可微时　可微性不是自动成立的。下面的引理不要求可微，并且给出了全局下界的完整刻画：所有能作全局下界斜率的向量，恰好就是全体最优乘子的相反数。

引理 19.4　下界斜率与最优乘子　设 $f^\star$ 有限，$\boldsymbol{\lambda}\in\mathbb{R}^m$，$\boldsymbol{\nu}\in\mathbb{R}^p$，$f,g_i,h_j$ 定义在同一集合 $\boldsymbol{D}$ 上，式 (19.7)及对偶函数中的 $\boldsymbol{x}$ 都取遍 $\boldsymbol{D}$。则下面两条等价：

1. $\boldsymbol{\lambda}\geq\mathbf{0}$，且 $q(\boldsymbol{\lambda},\boldsymbol{\nu})=f^\star$；
2. 对所有 $(\boldsymbol{u},\boldsymbol{v})$，都有

$$V(\boldsymbol{u},\boldsymbol{v})\geq f^\star-\langle\boldsymbol{\lambda},\boldsymbol{u}\rangle-\langle\boldsymbol{\nu},\boldsymbol{v}\rangle. \tag{19.11}$$

证明　第一条推出第二条，这就是定理 19.2。下面从第二条出发。先证明 $\lambda_i\geq0$。取 $t>0$，令 $\boldsymbol{u}=t\boldsymbol{e}_i$，$\boldsymbol{v}=\mathbf{0}$。放宽约束只会扩大可行集，所以 $V(t\boldsymbol{e}_i,\mathbf{0})\leq f^\star$。结合式 (19.11)，得到

$$f^\star\geq V(t\boldsymbol{e}_i,\mathbf{0})\geq f^\star-t\lambda_i.$$

所以 $\lambda_i\geq0$。

再证明 $q(\boldsymbol{\lambda},\boldsymbol{\nu})\geq f^\star$。任取 $\boldsymbol{x}\in\boldsymbol{D}$，令 $u_i=g_i(\boldsymbol{x})$，$v_j=h_j(\boldsymbol{x})$。这个 $\boldsymbol{x}$ 是这组扰动问题的可行点，所以 $f(\boldsymbol{x})\geq V(\boldsymbol{u},\boldsymbol{v})$。再由式 (19.11)，

$$f(\boldsymbol{x})\geq f^\star-\sum_i\lambda_i g_i(\boldsymbol{x})-\sum_j\nu_j h_j(\boldsymbol{x}).$$

移项得到

$$\mathcal{L}(\boldsymbol{x},\boldsymbol{\lambda},\boldsymbol{\nu})\geq f^\star.$$

对 $\boldsymbol{x}$ 取下确界，得到 $q(\boldsymbol{\lambda},\boldsymbol{\nu})\geq f^\star$。又由弱对偶 $q(\boldsymbol{\lambda},\boldsymbol{\nu})\leq f^\star$，所以两者相等。 ■

当 f 与 g_i 是凸函数、h_j 是仿射函数时，V 是凸函数。取两组扰动及各自的近优可行点，它们的凸组合对扰动的相应凸组合仍可行，目标值不超过相应的凸组合，由此就得到 V 的凸性。

这时式 (19.11)正是第 11章次梯度的定义，引理说的就是 $-(\boldsymbol{\lambda}, \boldsymbol{\nu})$ 属于 V 在原点的次微分。若原点还是 V 的定义域的内点，V 在方向 $(\boldsymbol{u}, \boldsymbol{v})$ 上的方向导数等于

$$V'(\mathbf{0}, \mathbf{0}; \boldsymbol{u}, \boldsymbol{v}) = \max_{(\boldsymbol{\lambda}, \boldsymbol{\nu}) \text{ 最优}} \big(-\langle \boldsymbol{\lambda}, \boldsymbol{u} \rangle - \langle \boldsymbol{\nu}, \boldsymbol{v} \rangle\big), \tag{19.12}$$

其中最大值取遍全部最优乘子。这个等式的证明需要用到凸函数方向导数与次微分的对偶关系，篇幅较长，读者可查阅[1]。它的含义是：每个方向上的真实变化率由“最不利”的乘子决定，单独一组乘子不能代表所有方向。

[1] R. T. Rockafellar, *Convex Analysis*, Princeton University Press, 1970

一个有折角的例子 考虑一维问题

$$\min_{x \in \mathbb{R}} \; -x \quad \text{s.t.} \quad x - 1 \le u, \;\; x - 1 \le 0.$$

两条约束在 $u = 0$ 时完全相同，$x^\star = 1$，$f^\star = -1$。Lagrange 函数是

$$\mathcal{L}(x, \boldsymbol{\lambda}) = (-1 + \lambda_1 + \lambda_2)x - \lambda_1 - \lambda_2.$$

$\lambda_1 + \lambda_2 \neq 1$ 时它对 x 无下界。$\lambda_1 + \lambda_2 = 1$ 时它恒等于 -1。所以最优乘子集合是线段 $\{\boldsymbol{\lambda} \ge \mathbf{0} : \lambda_1 + \lambda_2 = 1\}$，乘子不唯一。

右端扰动的最优值可以直接写出。$u \ge 0$ 时第二条约束决定解，$x = 1$；$u < 0$ 时第一条约束决定解，$x = 1 + u$。所以

$$V(u) = \max\{-1 - u, \; -1\}.$$

V 在 $u = 0$ 处有折角，左导数是 -1，右导数是 0。图 19.8(a) 中斜率在 $[-1, 0]$ 内的每条直线都是全局下界，它们恰好对应 (b) 中线段上的每个乘子。

由式 (19.12)，向右的方向导数 $V'(0; 1) = \max(-\lambda_1) = 0$，由 $\lambda_1 = 0$ 取到。向左的方向导数 $V'(0; -1) = \max \lambda_1 = 1$，由 $\lambda_1 = 1$ 取到。求解器如果返回对称的乘子 $(1/2, 1/2)$，那么 $-1/2$ 只是一个合法的下界斜率，不是任何方向上的导数。

19.1 含参问题
19.2 最优值的变化
19.2.1 约束右端的全局变化界
19.2.2 乘子的边际解释
19.2.3 目标参数的包络关系
19.2.4 一般含参约束
19.3 最优解的变化
19.4 分支变化
19.5 导数的计算与核验
19.6 本章小结

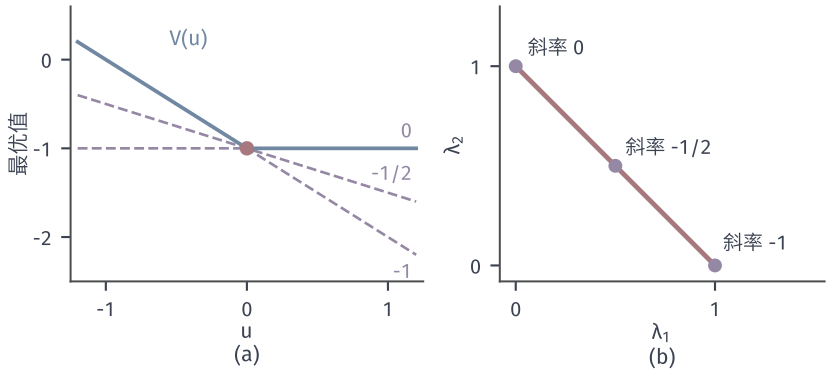


图 19.8 乘子不唯一时的值函数。(a) 蓝线是 $V(u)=\max\{-1-u,-1\}$，紫色虚线是斜率 $0,-1/2,-1$ 的全局下界，它们都穿过红点。(b) 红色线段是全体最优乘子，紫色点是图 (a) 三条直线对应的乘子。

表 19.1比较本节出现的三个量。

对象	成立条件	范围
下界斜率 $-\boldsymbol{\lambda}^\star$	零间隙且乘子达到	全局，单侧
实际导数 $-\boldsymbol{\lambda}^\star$	另加 V 在基准点可微	局部，一阶
方向导数	凸问题、基准点在定义域内部	局部，沿给定方向

表 19.1 约束右端扰动下的三个量。下界斜率来自任何一组最优乘子，实际导数要求 V 可微，方向导数要在全体最优乘子上取最大值。

19.2.3 目标参数的包络关系

现在让目标函数含参数，可行集固定。最优解随参数移动，所以最优值的变化似乎有两个来源：目标本身变了，最优点也动了。本小节的结论是，一阶意义下第二个来源不起作用。

谷底的一阶平坦 站在谷底，向任何方向走一小步，高度的一阶变化都是零。最优解被参数推着移动一小段，走的正是这样的一小步，所以高度的变化几乎全部来自地形本身的改变。这是整个包络关系的直观基础。

在边界上情况稍有不同：梯度不必为零，因为有约束挡住。但如果解沿着边界来回移动，它向两个相反的方向都是可行的，梯度只能与这个移动方向垂直。

定理 19.5 包络关系 设 $\boldsymbol{C} \subseteq \mathbb{R}^n$ 固定，f 在 $(\boldsymbol{x}_0, \theta_0)$ 的邻域内连续可微。设映射 $\boldsymbol{x}(\cdot)$ 定义在 θ_0 的邻域上，取值于 $\boldsymbol{C}$，在 θ_0 处可微，$\boldsymbol{x}(\theta_0) = \boldsymbol{x}_0$，且 $\boldsymbol{x}_0$ 是 $f(\cdot, \theta_0)$ 在 $\boldsymbol{C}$ 上的局部极小点。记 v 为式 (19.6)定义的分支值，则

$$\nabla v(\theta_0) = \nabla_\theta f(\boldsymbol{x}_0, \theta_0). \tag{19.13}$$

证明 记 $\boldsymbol{D}_{\boldsymbol{x}} \in \mathbb{R}^{n\times q}$ 是 $\boldsymbol{x}(\cdot)$ 在 θ_0 的 Jacobian 矩阵。由链式法则，

$$\nabla v(\theta_0) = \nabla_\theta f(\boldsymbol{x}_0, \theta_0) + \boldsymbol{D}_{\boldsymbol{x}}^{\top} \nabla_{\boldsymbol{x}} f(\boldsymbol{x}_0, \theta_0).$$

只需证明第二项为零。任取方向 $\boldsymbol{d} \in \mathbb{R}^q$，令

$$\psi(t) = f\big(\boldsymbol{x}(\theta_0 + t\boldsymbol{d}), \theta_0\big).$$

注意 ψ 里的参数固定在 θ_0。$|t|$ 很小时，$\boldsymbol{x}(\theta_0 + t\boldsymbol{d})$ 属于 $\boldsymbol{C}$ 且靠近 $\boldsymbol{x}_0$，所以 $\psi(t) \geq \psi(0)$。$t = 0$ 是 ψ 的内部极小点，$\psi'(0) = 0$，也就是

$$\big\langle \nabla_{\boldsymbol{x}} f(\boldsymbol{x}_0, \theta_0),\ \boldsymbol{D}_{\boldsymbol{x}} \boldsymbol{d} \big\rangle = 0.$$

$\boldsymbol{d}$ 是任意的，所以

$$\boldsymbol{D}_{\boldsymbol{x}}^{\top} \nabla_{\boldsymbol{x}} f(\boldsymbol{x}_0, \theta_0) = \boldsymbol{0}.$$

■

结论说的是分支上的值 v，而不是全局最优值 V。条件里最关键的是 $\boldsymbol{C}$ 固定：这样分支上的点对基准问题仍是可行的，才能用基准点的局部极小性。约束也含参数的情形放在第 19.2.4节。

预算例：理想点移动 把理想点改成 $(2+\theta, 1)$，预算固定为 $\tau = 2$，目标是

$$f(\boldsymbol{x}, \theta) = \frac{1}{2}(x_1 - 2 - \theta)^2 + \frac{1}{2}(x_2 - 1)^2.$$

$|\theta| < 1$ 时只有预算起作用。平稳条件是 $x_1 - 2 - \theta + \lambda = 0$、$x_2 - 1 + \lambda = 0$，与 $x_1 + x_2 = 2$ 联立，得到

$$\lambda = \frac{1+\theta}{2}, \qquad x_1(\theta) = \frac{3}{2} + \frac{\theta}{2}, \qquad x_2(\theta) = \frac{1}{2} - \frac{\theta}{2}.$$

分支上的值是 $v(\theta) = \lambda^2 = (1+\theta)^2/4$，直接求导得到 $v'(\theta) = (1+\theta)/2$。用包络关系，只需对目标中显含的 θ 求偏导：

$$\frac{\partial f}{\partial \theta} = 2 + \theta - x_1 = \frac{1+\theta}{2}.$$

两个结果一致。解的移动方向是 $\boldsymbol{x}'(\theta) = (1/2, -1/2)$，$\nabla_{\boldsymbol{x}} f = -\lambda(1,1)$，两者的内积确实为零。图 19.9(a) 显示，解沿预算线滑动，而负梯度垂直于这条线。

为什么叫包络 把决策 $\hat{\boldsymbol{x}}$ 固定，$\theta \mapsto f(\hat{\boldsymbol{x}}, \theta)$ 就是一条曲线。每个固定的决策对应一条这样的曲线，它们都在 $v(\theta)$ 上方，因为固定决策不会比最优决策好。图 19.9(b) 中 v 是这族曲线的下边缘，称为它们的包络，式 (19.13)因此称为**包络定理**（envelope theorem）。

曲线在切点处与 v 相切。切点处的斜率既是这条固定决策曲线的斜率，也是 v 的斜率，这正是“只对显含的 θ 求导”的图形含义。

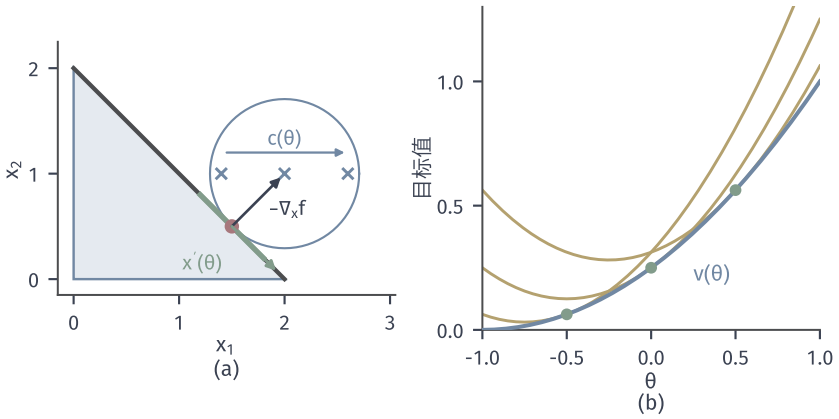


图 19.9 包络关系。(a) $\tau = 2$ 的可行集上，理想点沿蓝色箭头移动（蓝色叉是 $\theta = -0.6, 0, 0.6$），最优解沿绿色线段滑动。红点是 $\theta = 0$ 的解，黑色箭头是负梯度，绿色箭头是解的移动方向，两者垂直。(b) 黄线是把决策固定在 $\theta = -0.5, 0, 0.5$ 的最优解上得到的目标值，蓝线 $v(\theta)$ 是它们的下边缘，绿点是切点。

没有可微分支时 定理 19.5需要一条可微的解分支。若最优解不唯一，或最优解随参数跳动，这样的分支就没有了。但只要可行集紧，全局最优值的方向导数仍然有公式，这就是 Danskin 型结果。

定理 19.6 Danskin 型结果 设 $\boldsymbol{C} \subseteq \mathbb{R}^n$ 非空且紧，$\boldsymbol{\Theta} \subseteq \mathbb{R}^q$ 开，f 在 $\boldsymbol{C} \times \boldsymbol{\Theta}$ 上连续，关于 θ 的梯度 $\nabla_\theta f$ 存在且在 $\boldsymbol{C} \times \boldsymbol{\Theta}$ 上连续。记 V 为式 (19.3)在 $\boldsymbol{C}(\theta) \equiv \boldsymbol{C}$ 时的最优值函数，则对每个 $\theta \in \boldsymbol{\Theta}$ 与方向 $\boldsymbol{d}$，

$$V'(\theta; \boldsymbol{d}) = \min_{\boldsymbol{x} \in \boldsymbol{S}(\theta)} \langle \nabla_\theta f(\boldsymbol{x}, \theta), \boldsymbol{d} \rangle. \tag{19.14}$$

若 $\boldsymbol{S}(\theta) = \{\boldsymbol{x}^\star\}$ 只有一个点，则 V 在 θ 可微，且

$$\nabla V(\theta) = \nabla_\theta f(\boldsymbol{x}^\star, \theta). \tag{19.15}$$

证明　$\boldsymbol{S}(\theta)$ 是紧集 $\boldsymbol{C}$ 的闭子集，所以式 (19.14)的最小值可以取到。下面从两个方向夹逼。

先证上界。任取 $\boldsymbol{x} \in \boldsymbol{S}(\theta)$ 和 $t > 0$。$\boldsymbol{x}$ 对 $\theta + t\boldsymbol{d}$ 仍可行，而且在 θ 处最优，所以

$$V(\theta + t\boldsymbol{d}) \le f(\boldsymbol{x}, \theta + t\boldsymbol{d}), \qquad V(\theta) = f(\boldsymbol{x}, \theta).$$

由一元中值定理，存在 $\xi \in (0,1)$，使

$$\frac{V(\theta + t\boldsymbol{d}) - V(\theta)}{t} \le \left\langle \nabla_\theta f(\boldsymbol{x}, \theta + \xi t\boldsymbol{d}), \boldsymbol{d} \right\rangle.$$

令 $t \downarrow 0$, 由梯度的连续性, 上极限不超过 $\langle \nabla_\theta f(\boldsymbol{x}, \theta), \boldsymbol{d} \rangle$。再对 $\boldsymbol{x} \in \boldsymbol{S}(\theta)$ 取最小，就得到上界。

再证下界。取 $t_k \downarrow 0$, 使差商趋于它的下极限, 并取 $\boldsymbol{x}_k \in \boldsymbol{S}(\theta + t_k\boldsymbol{d})$。$\boldsymbol{C}$ 是紧集，可以取子列使 $\boldsymbol{x}_k \to \bar{\boldsymbol{x}} \in \boldsymbol{C}$。对任意 $\boldsymbol{y} \in \boldsymbol{C}$，$\boldsymbol{x}_k$ 的最优性给出

$$f(\boldsymbol{x}_k, \theta + t_k\boldsymbol{d}) \le f(\boldsymbol{y}, \theta + t_k\boldsymbol{d}).$$

令 $k \to \infty$ 并用 f 的连续性，可知 $\bar{\boldsymbol{x}}$ 在参数 θ 下的目标值不超过任何 $\boldsymbol{y} \in \boldsymbol{C}$ 的目标值，所以 $\bar{\boldsymbol{x}} \in \boldsymbol{S}(\theta)$。

此外，$\boldsymbol{x}_k$ 是基准问题的可行点，又在 $\theta + t_k\boldsymbol{d}$ 处最优，所以

$$V(\theta) \le f(\boldsymbol{x}_k, \theta), \qquad V(\theta + t_k\boldsymbol{d}) = f(\boldsymbol{x}_k, \theta + t_k\boldsymbol{d}).$$

再用一次中值定理，存在 $\xi_k \in (0,1)$，使

$$\frac{V(\theta + t_k\boldsymbol{d}) - V(\theta)}{t_k} \ge \left\langle \nabla_\theta f(\boldsymbol{x}_k, \theta + \xi_k t_k\boldsymbol{d}), \boldsymbol{d} \right\rangle.$$

令 $k \to \infty$，下极限不小于 $\langle \nabla_\theta f(\bar{\boldsymbol{x}}, \theta), \boldsymbol{d} \rangle$，它又不小于式 (19.14)的右端。上下界合起来，方向导数存在并等于右端。

只有一个解时，把上面两步中的 $t\boldsymbol{d}$ 换成趋于零的向量 δ。上界一步给出

$$V(\theta + \delta) - V(\theta) \le \langle \nabla_\theta f(\boldsymbol{x}^\star, \theta), \delta \rangle + o(\|\delta\|_2).$$

下界一步中 $\boldsymbol{x}_\delta \to \boldsymbol{x}^\star$，因为任何极限点都属于单点集 $\boldsymbol{S}(\theta)$，于是相同的表达式也是下界。所以 V 可微。 ■

式 (19.14)取的是最小值，这与目标是最小化相对应。直观上，参数沿 $\boldsymbol{d}$ 变化时，全部最优解处在同一起跑线上，下一时刻仍然留在最优的，是在方向 $\boldsymbol{d}$ 上目标增长最慢的那一个。

19.1 含参问题
19.2 最优值的变化
19.2.1 约束右端的全局变化界
19.2.2 乘子的边际解释
19.2.3 目标参数的包络关系
19.2.4 一般含参约束
19.3 最优解的变化
19.4 分支变化
19.5 导数的计算与核验
19.6 本章小结

条件的作用：多解时的方向导数 考虑线性目标 $f(\boldsymbol{x},p)=-px_1-x_2$，可行集是 $\tau=2$ 的三角形。$p>1$ 时最优点是 $(2,0)$，$p<1$ 时最优点是 $(0,2)$，$p=1$ 时整条预算线都是最优解，见图 19.10。最优值是

$$V(p)=-2\max\{p,1\}.$$

在 $p=1$ 处，$\partial f/\partial p=-x_1$。式 (19.14)给出

$$V'(1;1)=\min_{\boldsymbol{x}\in S(1)}(-x_1)=-2,\qquad V'(1;-1)=\min_{\boldsymbol{x}\in S(1)}x_1=0.$$

第一个由顶点 $(2,0)$ 取到，第二个由顶点 $(0,2)$ 取到，与图中两段的斜率一致。

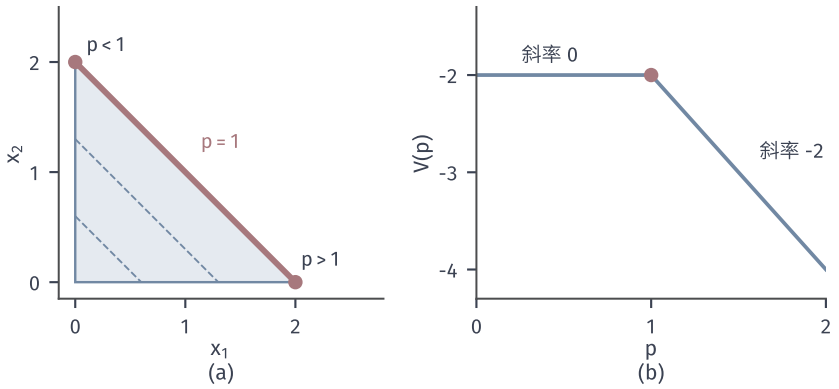


图 19.10 线性目标 $-px_1-x_2$ 在三角形 $x_1+x_2\le 2$，$\boldsymbol{x}\ge\mathbf{0}$ 上的最优解。(a) $p=1$ 时蓝色虚线的等值线平行于预算线，红色粗线上的点都最优；$p>1$ 或 $p<1$ 时解是相应的红色顶点。(b) 最优值 $V(p)=-2\max\{p,1\}$ 在 $p=1$ 有折角。

紧性不能随意去掉。第 19.1节的 $f(x,\theta)=e^x-\theta x$ 在 $\theta=0$ 处没有最优解，式 (19.14)的右端失去意义。实际上 $\theta>0$ 时 $V(\theta)=\theta-\theta\ln\theta$，所以

$$\frac{V(\theta)-V(0)}{\theta}=1-\ln\theta\to+\infty\quad(\theta\downarrow 0),$$

V 在 $\theta=0$ 处的右导数不是有限数。

19.2.4 一般含参约束

现在目标和约束都含参数。可行集随参数移动，上一小节的证明不能直接用，因为分支上的点对基准问题已经不可行。本小节说明，对沿分支的值求导时，Lagrange 函数吸收了约束移动的贡献。

从目标到 Lagrange 函数 考虑一族问题

$$\min_{\boldsymbol{x}} \; f(\boldsymbol{x},\boldsymbol{\theta}) \quad \text{s.t.} \quad g_i(\boldsymbol{x},\boldsymbol{\theta}) \le 0,\; h_j(\boldsymbol{x},\boldsymbol{\theta}) = 0, \tag{19.16}$$

其 Lagrange 函数 $\mathcal{L}(\boldsymbol{x},\boldsymbol{\lambda},\boldsymbol{\nu},\boldsymbol{\theta})$ 也含参数。下面的定理假设已经有一条 KKT 点分支，并且起作用的约束保持起作用。这条分支从何而来，由第 19.3节回答。

定理 19.7 分支值对参数的导数 设 f, g_i, h_j 在 $(\boldsymbol{x}_0,\boldsymbol{\theta}_0)$ 的邻域内连续可微。设映射 $\boldsymbol{x}(\cdot)$ 在 $\boldsymbol{\theta}_0$ 的邻域上满足 $\boldsymbol{x}(\boldsymbol{\theta}_0) = \boldsymbol{x}_0$，在 $\boldsymbol{\theta}_0$ 可微，$(\boldsymbol{x}_0,\boldsymbol{\lambda}_0,\boldsymbol{\nu}_0)$ 在 $\boldsymbol{\theta}_0$ 处满足平稳条件，且沿分支恒有

$$g_i(\boldsymbol{x}(\boldsymbol{\theta}),\boldsymbol{\theta}) = 0 \;\; (\lambda_{0,i} > 0), \qquad h_j(\boldsymbol{x}(\boldsymbol{\theta}),\boldsymbol{\theta}) = 0. \tag{19.17}$$

记 v 为式 (19.6)定义的分支值，则

$$\nabla v(\boldsymbol{\theta}_0) = \nabla_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{x}_0,\boldsymbol{\lambda}_0,\boldsymbol{\nu}_0,\boldsymbol{\theta}_0). \tag{19.18}$$

证明 下面所有函数都在 $(\boldsymbol{x}_0,\boldsymbol{\theta}_0)$ 取值，$\boldsymbol{D}_{\boldsymbol{x}}$ 是分支的 Jacobian 矩阵。由链式法则，

$$\nabla v = \nabla_{\boldsymbol{\theta}} f + \boldsymbol{D}_{\boldsymbol{x}}^{\top} \nabla_{\boldsymbol{x}} f.$$

用平稳条件替换 $\nabla_{\boldsymbol{x}} f$，乘子为零的项自动消失：

$$\boldsymbol{D}_{\boldsymbol{x}}^{\top} \nabla_{\boldsymbol{x}} f = -\sum_i \lambda_{0,i} \boldsymbol{D}_{\boldsymbol{x}}^{\top} \nabla_{\boldsymbol{x}} g_i - \sum_j \nu_{0,j} \boldsymbol{D}_{\boldsymbol{x}}^{\top} \nabla_{\boldsymbol{x}} h_j.$$

对恒等式 $g_i(\boldsymbol{x}(\boldsymbol{\theta}),\boldsymbol{\theta}) = 0$ 求导，得到

$$\boldsymbol{D}_{\boldsymbol{x}}^{\top} \nabla_{\boldsymbol{x}} g_i + \nabla_{\boldsymbol{\theta}} g_i = \boldsymbol{0}.$$

等式约束同样如此。代回上一式，得到

$$\boldsymbol{D}_{\boldsymbol{x}}^{\top} \nabla_{\boldsymbol{x}} f = \sum_i \lambda_{0,i} \nabla_{\boldsymbol{\theta}} g_i + \sum_j \nu_{0,j} \nabla_{\boldsymbol{\theta}} h_j.$$

加上 $\nabla_{\boldsymbol{\theta}} f$，右端就是 $\nabla_{\boldsymbol{\theta}} \mathcal{L}$。 ∎

式 (19.18)包含两部分贡献。$\nabla_{\boldsymbol{\theta}} f$ 是目标本身的变化，$\sum \lambda_i \nabla_{\boldsymbol{\theta}} g_i$ 是约束移动造成的变化，乘子把约束的移动折算成目标的变化。若约束不含参数，第二部分为零，回到包络关系。若 $g_1 = x_1 + x_2 - \tau$，则 $\partial g_1/\partial \tau = -1$，式 (19.18)给出 $v'(\tau) = -\lambda_1$，回到边际解释。

一个目标与约束同时含参的例子 让参数 θ 同时影响目标和预算的价格：

$$\min_{\boldsymbol{x}} \ \frac{1}{2}(x_1 - 1 - \theta)^2 + \frac{1}{2}(x_2 - 1)^2 \quad \text{s.t.} \quad \theta x_1 + x_2 - 2 \le 0.$$

$\theta = 1$ 时它就是 $\tau = 2$ 的预算例。θ 变大时，第一种投入的单价上涨，预算线绕 $(0, 2)$ 转动，理想点也同时右移，见图 19.11。

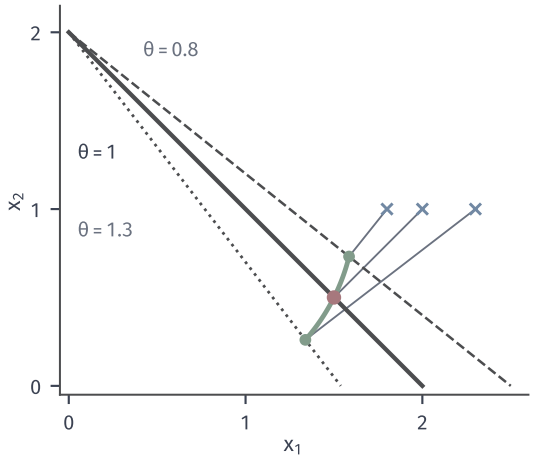


图 19.11 目标与约束同时含参。三条深灰线是 $\theta = 0.8, 1, 1.3$ 的预算线 $\theta x_1 + x_2 = 2$，蓝色叉是相应的理想点 $(1 + \theta, 1)$，细灰线连接理想点和最优解。绿色曲线是最优解随 θ 的路径，红点是 $\theta = 1$ 的解。

预算约束起作用时，平稳条件是 $x_1 - 1 - \theta + \lambda\theta = 0$、$x_2 - 1 + \lambda = 0$。把 $x_1 = 1 + \theta - \lambda\theta$ 与 $x_2 = 1 - \lambda$ 代入 $\theta x_1 + x_2 = 2$，解出

$$\lambda(\theta) = \frac{\theta^2 + \theta - 1}{1 + \theta^2}.$$

$\theta = 1$ 时 $\lambda = 1/2$，$\boldsymbol{x} = (3/2, 1/2)$。

用式 (19.18)，目标与约束的偏导数分别是

$$\frac{\partial f}{\partial \theta} = -(x_1 - 1 - \theta) = \lambda\theta = \frac{1}{2}, \qquad \lambda \frac{\partial g}{\partial \theta} = \lambda x_1 = \frac{3}{4}.$$

相加得到 $v'(1) = 5/4$。目标的直接变化贡献 $1/2$，价格上涨使约束收紧，贡献 $3/4$。

直接核对：把解代入目标，得到 $v(\theta) = \frac{1}{2}\lambda^2(1 + \theta^2)$，即

$$v(\theta) = \frac{(\theta^2 + \theta - 1)^2}{2(1 + \theta^2)}.$$

19.1 含参问题
19.2 最优值的变化
19.3 最优解的变化
19.3.1 无约束极小解
19.3.2 等式约束极小解
19.3.3 不等式约束极小解
19.4 分支变化
19.5 导数的计算与核验
19.6 本章小结

在 $\theta=1$ 处求导，分子 $N=\theta^2+\theta-1$ 满足 $N=1$，$N'=3$，分母 $D=1+\theta^2$ 满足 $D=2$，$D'=2$，所以

$$v'(1)=\frac{NN'}{D}-\frac{N^2D'}{2D^2}=\frac{3}{2}-\frac{1}{4}=\frac{5}{4}.$$

两个结果一致。式 (19.18)不需要先解出分支，只需要基准点的 $\boldsymbol{x}$ 和乘子。

19.3 最优解的变化

最优值是一个数，最优解是一个向量，后者需要更多的结构才能求导。这就需要回答：选定一个解之后，它随参数怎样移动？办法是把这个解满足的最优性条件看成一组方程，方程里既有原变量和乘子，也有参数，然后像解隐函数那样求局部导数。

隐函数定理的回顾 所用的工具是隐函数定理：设 $\boldsymbol{F}(\boldsymbol{z},\theta)$ 连续可微，$\boldsymbol{F}(\boldsymbol{z}_0,\theta_0)=\boldsymbol{0}$，方阵 $\boldsymbol{D}_{\boldsymbol{z}}\boldsymbol{F}(\boldsymbol{z}_0,\theta_0)$ 可逆。则在 θ_0 附近有唯一的连续可微映射 $\boldsymbol{z}(\theta)$，使 $\boldsymbol{z}(\theta_0)=\boldsymbol{z}_0$，且在 $(\boldsymbol{z}_0,\theta_0)$ 的某个邻域内方程的解全部落在这条曲线上。它的导数满足线性方程

$$\boldsymbol{D}_{\boldsymbol{z}}\boldsymbol{F}\cdot\boldsymbol{D}\boldsymbol{z}=-\boldsymbol{D}_{\theta}\boldsymbol{F}.$$

定理的陈述与证明可参考卷二第 22 章“隐函数与反函数”。

用它研究极小点时要多一步检查，因为隐函数定理只管方程。例如 $f(x,\theta)=-x^2/2+\theta x$ 的驻点方程是 $-x+\theta=0$，导数 -1 可逆，隐函数定理给出光滑分支 $x(\theta)=\theta$，而这条分支上全是极大点。所以下面每个定理都分成两部分：方程有光滑解，以及这个解确实是极小点。

19.3.1 无约束极小解

碗的曲率决定碗底移动的距离 无约束时，$\boldsymbol{x}^\star$ 是碗底，满足 $\nabla_{\boldsymbol{x}}f=\boldsymbol{0}$。参数一变，梯度在原来的位置上不再为零，碗底要移动到新的梯度零点。线性近似告诉我们移动多少：

$$\nabla^2_{\boldsymbol{x}\boldsymbol{x}}f\cdot\Delta\boldsymbol{x}+\nabla^2_{\boldsymbol{x}\theta}f\cdot\Delta\theta\approx\boldsymbol{0}.$$

曲率大的方向，碗壁陡，碗底只需移动一点就能抵消参数带来的梯度变化；曲率小的方向，碗底要移动很远。

定理 19.8 无约束极小解的导数 设 f 在 $(\boldsymbol{x}_0, \theta_0)$ 的邻域内二阶连续可微，$\nabla_{\boldsymbol{x}} f(\boldsymbol{x}_0, \theta_0) = \boldsymbol{0}$，$\nabla^2_{\boldsymbol{xx}} f(\boldsymbol{x}_0, \theta_0) \succ \boldsymbol{0}$。则存在 θ_0 的邻域和唯一的连续可微映射 $\boldsymbol{x}(\cdot)$，使 $\boldsymbol{x}(\theta_0) = \boldsymbol{x}_0$，且邻域内的每个 $\boldsymbol{x}(\theta)$ 都是 $f(\cdot, \theta)$ 的严格局部极小点。Jacobian 矩阵 $\boldsymbol{D}_{\boldsymbol{x}} \in \mathbb{R}^{n\times q}$ 由线性方程

$$\nabla^2_{\boldsymbol{xx}} f \cdot \boldsymbol{D}_{\boldsymbol{x}} = -\nabla^2_{\boldsymbol{x}\theta} f \tag{19.19}$$

确定，其中各导数都在 $(\boldsymbol{x}(\theta), \theta)$ 处取值。

证明 令 $\boldsymbol{F} = \nabla_{\boldsymbol{x}} f$。$f$ 二阶连续可微，所以 $\boldsymbol{F}$ 连续可微。$\boldsymbol{D}_{\boldsymbol{x}} \boldsymbol{F} = \nabla^2_{\boldsymbol{xx}} f$ 在基准点正定，因而可逆。隐函数定理给出连续可微的分支 $\boldsymbol{x}(\theta)$，对恒等式 $\boldsymbol{F}(\boldsymbol{x}(\theta), \theta) = \boldsymbol{0}$ 求导就得到式 (19.19)。

再说明它是极小点。Hessian 矩阵连续依赖于 $(\boldsymbol{x}, \theta)$，矩阵的最小特征值连续，所以 θ 靠近 θ_0 时，$\nabla^2_{\boldsymbol{xx}} f(\boldsymbol{x}(\theta), \theta)$ 仍然正定。驻点处 Hessian 正定，由第 5章的二阶充分条件，$\boldsymbol{x}(\theta)$ 是严格局部极小点。 ■

定理是局部的，Hessian 正定只说明这条分支是局部极小，它不保证全局最优。正定性也不能减弱成可逆：上面驻点是极大点的例子中，Hessian 可逆但负定。

例子：带二次惩罚的最小二乘 取 $\boldsymbol{A}$ 和 $\boldsymbol{b}$ 如下，并用 $\gamma > 0$ 作正则系数：

$$\boldsymbol{A} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}, \qquad \boldsymbol{b} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}, \qquad f(\boldsymbol{x}, \gamma) = \frac{1}{2}\|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|_2^2 + \frac{\gamma}{2}\|\boldsymbol{x}\|_2^2.$$

梯度为零的方程是 $\boldsymbol{H}(\gamma)\boldsymbol{x} = \boldsymbol{A}^{\top}\boldsymbol{b}$，其中

$$\boldsymbol{H}(\gamma) = \boldsymbol{A}^{\top}\boldsymbol{A} + \gamma \boldsymbol{I} = \begin{bmatrix} 2+\gamma & 1 \\ 1 & 1+\gamma \end{bmatrix}, \qquad \boldsymbol{A}^{\top}\boldsymbol{b} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

$\gamma > 0$ 时 $\boldsymbol{H}(\gamma)$ 正定，所以全局最优解存在且唯一，条件满足。在 $\gamma = 1$ 处，求 $\boldsymbol{H}$ 的逆矩阵，得到

$$\boldsymbol{H}(1) = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}, \qquad \boldsymbol{H}(1)^{-1} = \frac{1}{5}\begin{bmatrix} 2 & -1 \\ -1 & 3 \end{bmatrix}, \qquad \boldsymbol{x}(1) = \begin{bmatrix} 2/5 \\ 4/5 \end{bmatrix}.$$

梯度 $\boldsymbol{H}(\gamma)\boldsymbol{x} - \boldsymbol{A}^{\top}\boldsymbol{b}$ 对 γ 的偏导数是 $\boldsymbol{x}$ 本身。于是式 (19.19)给出

$$\boldsymbol{x}'(1) = -\boldsymbol{H}(1)^{-1}\boldsymbol{x}(1) = \begin{bmatrix} 0 \\ -2/5 \end{bmatrix}.$$

γ 增大时，解在这一点上只往 x_2 减小的方向移动，x_1 的一阶变化恰好为零。显式解是

$$x_1(\gamma) = \frac{2\gamma}{1 + 3\gamma + \gamma^2}, \qquad x_2(\gamma) = \frac{2 + 2\gamma}{1 + 3\gamma + \gamma^2},$$

直接求导可以验证同一结果，$x_1(\gamma)$ 恰在 $\gamma = 1$ 达到最大。

局部导数与有限跳变 一阶预测 $\boldsymbol{x}(1) + (\gamma - 1)\boldsymbol{x}'(1)$ 的可信范围是有限的。$\gamma = 1.1$ 时，真解和预测分别是

$$\boldsymbol{x}(1.1) \approx (0.3993,\ 0.7623), \qquad \boldsymbol{x}(1) + 0.1\,\boldsymbol{x}'(1) = (0.4,\ 0.76).$$

两者很接近。$\gamma = 3$ 时，真解是 $(6/19, 8/19) \approx (0.316, 0.421)$，而预测是 $(0.4, 0)$，差得很远。图 19.12显示了原因：解的路径是弯的，切线只在基准点附近贴着它。

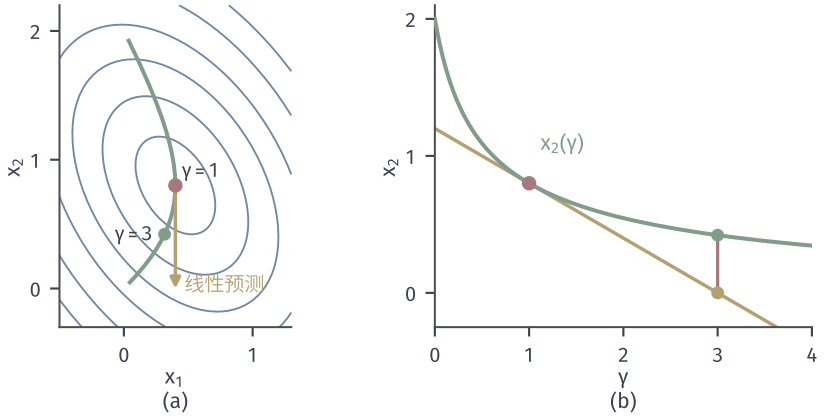


图 19.12 带二次惩罚的最小二乘的解随 γ 的移动。(a) 蓝线是 $\gamma = 1$ 的目标等高线，绿色曲线是解的路径，红点是 $\boldsymbol{x}(1)$，绿点是 $\boldsymbol{x}(3)$，黄色箭头是导数给出的线性预测。(b) $x_2(\gamma)$（绿线）与它在 $\gamma = 1$ 的切线（黄线），红色线段是 $\gamma = 3$ 处的预测误差。

导数回答的是无穷小的变化。有限跳变需要另外的工具。下面的结论不需要解分支可微，对任意大小的参数差都成立。

定理 19.9 强凸情形的有限跳变界 设对 $\theta \in \{\theta_0, \theta_1\}$，$f(\cdot, \theta)$ 在 $\mathbb{R}^n$ 上可微，$\boldsymbol{x}_0$、$\boldsymbol{x}_1$ 分别是 $f(\cdot, \theta_0)$、$f(\cdot, \theta_1)$ 的最小点，且 $f(\cdot, \theta_1)$ 是 μ 强凸的。则

$$\|\boldsymbol{x}_1 - \boldsymbol{x}_0\|_2 \le \frac{1}{\mu}\left\|\nabla_{\boldsymbol{x}} f(\boldsymbol{x}_0, \theta_1) - \nabla_{\boldsymbol{x}} f(\boldsymbol{x}_0, \theta_0)\right\|_2. \tag{19.20}$$

证明 强凸函数的梯度满足

$$\langle \nabla_{\boldsymbol{x}} f(\boldsymbol{x}_1,\theta_1) - \nabla_{\boldsymbol{x}} f(\boldsymbol{x}_0,\theta_1),\ \boldsymbol{x}_1-\boldsymbol{x}_0\rangle \ge \mu\|\boldsymbol{x}_1-\boldsymbol{x}_0\|_2^2.$$

$\boldsymbol{x}_1$ 是 $f(\cdot,\theta_1)$ 的最小点，所以左端第一个梯度为零。$\boldsymbol{x}_0$ 是基准问题的最小点，零向量 $\nabla_{\boldsymbol{x}} f(\boldsymbol{x}_0,\theta_0)$ 可以加进去而不改变左端。于是

$$\mu\|\boldsymbol{x}_1-\boldsymbol{x}_0\|_2^2 \le \langle \nabla_{\boldsymbol{x}} f(\boldsymbol{x}_0,\theta_0) - \nabla_{\boldsymbol{x}} f(\boldsymbol{x}_0,\theta_1),\ \boldsymbol{x}_1-\boldsymbol{x}_0\rangle.$$

用 Cauchy–Schwarz 不等式放大右端，再除以 $\|\boldsymbol{x}_1-\boldsymbol{x}_0\|_2$（为零时结论直接成立），就得到式 (19.20)。 ■

式 (19.20)右端衡量“新目标在旧解处的梯度有多大”，$1/\mu$ 把这个梯度折算成距离，这与隐式导数中的逆 Hessian 起同样的作用。

在岭回归的例子里，$\gamma_0=1$，$\gamma_1=3$，新旧目标在 $\boldsymbol{x}_0$ 处的梯度差是 $(\gamma_1-\gamma_0)\boldsymbol{x}_0$，强凸常数是

$$\mu = 3 + \lambda_{\min}(\boldsymbol{A}^{\top}\boldsymbol{A}) = 3 + \frac{3-\sqrt{5}}{2}.$$

算出的上界和真实距离分别是

$$\frac{2\|\boldsymbol{x}_0\|_2}{\mu} \approx 0.529, \qquad \|\boldsymbol{x}(3)-\boldsymbol{x}(1)\|_2 \approx 0.388.$$

真实距离没有超过上界。

预测误差受三阶信息控制 一阶预测的误差要看导数变化得多快。下面的情形最容易说清楚：参数以线性项进入目标。

定理 19.10 线性扰动下的预测误差 设 $\varphi:\mathbb{R}^n\to\mathbb{R}$ 二阶连续可微、μ 强凸，$\nabla^2\varphi$ 是 M-Lipschitz 连续的。令

$$f(\boldsymbol{x},\theta) = \varphi(\boldsymbol{x}) - \langle \theta, \boldsymbol{x}\rangle, \tag{19.21}$$

$\boldsymbol{x}(\theta)$ 是唯一最小点，$\boldsymbol{H}=\nabla^2\varphi(\boldsymbol{x}(\theta))$。则对任意 $\boldsymbol{\Delta}\in\mathbb{R}^n$，

$$\left\|\boldsymbol{x}(\theta+\boldsymbol{\Delta}) - \boldsymbol{x}(\theta) - \boldsymbol{H}^{-1}\boldsymbol{\Delta}\right\|_2 \le \frac{M}{2\mu^3}\|\boldsymbol{\Delta}\|_2^2. \tag{19.22}$$

19.1 含参问题
19.2 最优值的变化
19.3 最优解的变化
19.3.1 无约束极小解
19.3.2 等式约束极小解
19.3.3 不等式约束极小解
19.4 分支变化
19.5 导数的计算与核验
19.6 本章小结

证明 记 $\boldsymbol{x} = \boldsymbol{x}(\theta)$，$\boldsymbol{p} = \boldsymbol{x}(\theta + \boldsymbol{\Delta}) - \boldsymbol{x}$。两点的驻点方程相减，得到

$$\nabla \varphi(\boldsymbol{x} + \boldsymbol{p}) - \nabla \varphi(\boldsymbol{x}) = \boldsymbol{\Delta}.$$

把左端写成 Hessian 矩阵的积分，再用 Lipschitz 条件，得到

$$\left\| \nabla \varphi(\boldsymbol{x} + \boldsymbol{p}) - \nabla \varphi(\boldsymbol{x}) - \boldsymbol{H}\boldsymbol{p} \right\|_2 \le \frac{M}{2} \|\boldsymbol{p}\|_2^2,$$

也就是

$$\|\boldsymbol{\Delta} - \boldsymbol{H}\boldsymbol{p}\|_2 \le \frac{M}{2} \|\boldsymbol{p}\|_2^2.$$

$\boldsymbol{H}$ 的最小特征值不小于 μ，所以两边乘以 $\boldsymbol{H}^{-1}$ 后，

$$\|\boldsymbol{H}^{-1}\boldsymbol{\Delta} - \boldsymbol{p}\|_2 \le \frac{M}{2\mu} \|\boldsymbol{p}\|_2^2.$$

再用定理 19.9。这里梯度差的范数恰好是 $\|\boldsymbol{\Delta}\|_2$，所以

$$\|\boldsymbol{p}\|_2 \le \frac{1}{\mu} \|\boldsymbol{\Delta}\|_2.$$

代入上式，就得到式 (19.22)。 ■

$M = 0$ 时目标是二次的，预测对任意大小的 $\boldsymbol{\Delta}$ 都精确。上面最小二乘例子中，$\boldsymbol{b}$ 的变化正是这种情形：$\boldsymbol{x}$ 是 $\boldsymbol{b}$ 的线性函数，一阶预测不会有误差。γ 的变化不属于线性扰动，因为它改变了曲率本身，这正是图 19.12中路径弯曲的原因。

19.3.2 等式约束极小解

有等式约束时，极小点不再是梯度的零点，而是 Lagrange 函数的驻点，方程组里要把乘子一并算上。本小节要说明，所需的正定性只需在约束的切空间上成立。

联合方程 考虑

$$\min_{\boldsymbol{x}} \ f(\boldsymbol{x}, \theta) \quad \text{s.t.} \quad \boldsymbol{h}(\boldsymbol{x}, \theta) = \boldsymbol{0}, \qquad \boldsymbol{h} : \mathbb{R}^n \times \mathbb{R}^q \to \mathbb{R}^p.$$

解 $\boldsymbol{x}$ 和乘子 $\boldsymbol{\nu}$ 同时满足平稳条件和可行条件，共 $n + p$ 个方程，未知量也是 $n + p$ 个：

$$\boldsymbol{F}(\boldsymbol{x}, \boldsymbol{\nu}, \theta) = \begin{bmatrix} \nabla_{\boldsymbol{x}} \mathcal{L}(\boldsymbol{x}, \boldsymbol{\nu}, \theta) \\ \boldsymbol{h}(\boldsymbol{x}, \theta) \end{bmatrix} = \boldsymbol{0}. \tag{19.23}$$

记 $\boldsymbol{W} = \nabla^2_{\boldsymbol{xx}}\mathcal{L}$，$\boldsymbol{J} = \boldsymbol{D}_{\boldsymbol{x}}\boldsymbol{h}$（$p \times n$ 矩阵，第 j 行是 $\nabla_{\boldsymbol{x}} h_j^{\top}$）。$\boldsymbol{F}$ 关于 $(\boldsymbol{x}, \boldsymbol{\nu})$ 的 Jacobian 矩阵是

$$\boldsymbol{K} = \begin{bmatrix} \boldsymbol{W} & \boldsymbol{J}^{\top} \\ \boldsymbol{J} & \boldsymbol{0} \end{bmatrix}. \tag{19.24}$$

称为KKT 矩阵（KKT matrix）。隐函数定理需要它可逆。下面的引理说明，这正是约束梯度独立和切空间曲率为正共同保证的。

引理 19.11　KKT 矩阵可逆　设 $\boldsymbol{J} \in \mathbb{R}^{r \times n}$ 行满秩，$\boldsymbol{W} \in \mathbb{R}^{n \times n}$ 对称，并且对每个满足 $\boldsymbol{J}\boldsymbol{d} = \boldsymbol{0}$ 的非零向量 $\boldsymbol{d}$，都有 $\boldsymbol{d}^{\top}\boldsymbol{W}\boldsymbol{d} > 0$。则式 (19.24)的矩阵 $\boldsymbol{K}$ 可逆。

证明　$\boldsymbol{K}$ 是方阵，只需证明它的零空间只含零向量。设 $\boldsymbol{K}$ 作用在 $(\boldsymbol{d}, \boldsymbol{w})$ 上为零，也就是

$$\boldsymbol{W}\boldsymbol{d} + \boldsymbol{J}^{\top}\boldsymbol{w} = \boldsymbol{0}, \qquad \boldsymbol{J}\boldsymbol{d} = \boldsymbol{0}.$$

用 $\boldsymbol{d}^{\top}$ 左乘第一式，再用第二式，得到

$$\boldsymbol{d}^{\top}\boldsymbol{W}\boldsymbol{d} = -(\boldsymbol{J}\boldsymbol{d})^{\top}\boldsymbol{w} = 0.$$

由切空间上的正定性，$\boldsymbol{d} = \boldsymbol{0}$。第一式于是成为 $\boldsymbol{J}^{\top}\boldsymbol{w} = \boldsymbol{0}$。$\boldsymbol{J}$ 行满秩，所以 $\boldsymbol{w} = \boldsymbol{0}$。 ■

两个条件的分工很清楚。正定性排除了沿约束方向走而曲率为零的情形，行满秩排除了乘子有多种取法的情形。

定理 19.12　等式约束极小解的导数　设 $f, \boldsymbol{h}$ 在 $(\boldsymbol{x}_0, \theta_0)$ 的邻域内二阶连续可微，$(\boldsymbol{x}_0, \boldsymbol{\nu}_0)$ 在 θ_0 处满足式 (19.23)，$\boldsymbol{J}$ 行满秩，且 $\boldsymbol{W}$ 在 $\ker \boldsymbol{J}$ 上正定。则存在 θ_0 的邻域和唯一的连续可微映射 $(\boldsymbol{x}(\cdot), \boldsymbol{\nu}(\cdot))$，满足式 (19.23)并经过基准点，每个 $\boldsymbol{x}(\theta)$ 都是相应问题的严格局部极小点，乘子唯一。导数满足

$$\begin{bmatrix} \boldsymbol{W} & \boldsymbol{J}^{\top} \\ \boldsymbol{J} & \boldsymbol{0} \end{bmatrix} \begin{bmatrix} \boldsymbol{D}_{\boldsymbol{x}} \\ \boldsymbol{D}_{\boldsymbol{\nu}} \end{bmatrix} = -\begin{bmatrix} \nabla^2_{\boldsymbol{x}\theta}\mathcal{L} \\ \boldsymbol{D}_{\theta}\boldsymbol{h} \end{bmatrix}. \tag{19.25}$$

证明　由引理 19.11，$\boldsymbol{K}$ 在基准点可逆。$f, \boldsymbol{h}$ 二阶连续可微，所以 $\boldsymbol{F}$ 连续可微，隐函数定理给出分支，对恒等式 $\boldsymbol{F} = \boldsymbol{0}$ 求导就得到式 (19.25)。

下面说明两个条件在基准点附近保持。行满秩是开条件，因为某个 p 阶子式不为零，它在附近仍不为零。

对切空间上的正定性用反证法。若有 $\theta_k \to \theta_0$，以及单位向量 $\boldsymbol{d}_k$，满足 $\boldsymbol{J}_k \boldsymbol{d}_k = \boldsymbol{0}$，$\boldsymbol{d}_k^{\top} \boldsymbol{W}_k \boldsymbol{d}_k \le 0$，取收敛子列 $\boldsymbol{d}_k \to \boldsymbol{d}$，则 $\boldsymbol{J}\boldsymbol{d} = \boldsymbol{0}$，$\boldsymbol{d}^{\top}\boldsymbol{W}\boldsymbol{d} \le 0$，$\|\boldsymbol{d}\|_2 = 1$，这与假设矛盾。

于是分支上每一点都满足第 17章的二阶充分条件：KKT 点处，Lagrange Hessian 在约束切空间上正定，保证该点是严格局部极小点。乘子由 $\boldsymbol{J}^{\top}\boldsymbol{\nu} = -\nabla_{\boldsymbol{x}} f$ 和行满秩唯一确定。 ■

预算线上的例子 把预算例的预算约束写成等式 $x_1 + x_2 - \tau = 0$，$\boldsymbol{W} = \boldsymbol{I}$，$\boldsymbol{J} = (1, 1)$，$\partial h / \partial \tau = -1$，$\nabla^2_{\boldsymbol{x}\tau} \mathcal{L} = \boldsymbol{0}$。式 (19.25)写成

$$\begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} x_1' \\ x_2' \\ \nu' \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

前两行说明 $x_1' = x_2' = -\nu'$，第三行给出 $2x_1' = 1$。于是

$$x_1' = x_2' = \frac{1}{2}, \qquad \nu' = -\frac{1}{2}.$$

多一单位预算平均分给两种投入，因为二次损失在两个方向上曲率相同。

整个空间上不必正定 这个例子的 $\boldsymbol{W}$ 碰巧正定，下面的例子不是。在预算线上使乘积最大，等价于

$$\min_{\boldsymbol{x}} \; -x_1 x_2 \quad \text{s.t.} \quad h(\boldsymbol{x}, \theta) = \theta x_1 + x_2 - 2 = 0,$$

参数 θ 是第一种投入的价格。先取基准 $\theta = 1$。平稳条件是 $-x_2 + \nu\theta = 0$、$-x_1 + \nu = 0$，与约束联立，得到

$$x_1(\theta) = \frac{1}{\theta}, \qquad x_2(\theta) = 1, \qquad \nu(\theta) = \frac{1}{\theta}.$$

基准点是 $\boldsymbol{x}_0 = (1, 1)$，$\nu_0 = 1$。$\boldsymbol{W}$ 的特征值是 ± 1，它不定，而切方向 $\boldsymbol{d} = (1, -1)$ 上

$$\boldsymbol{W} = \begin{bmatrix} 0 & -1 \\ -1 & 0 \end{bmatrix}, \qquad \boldsymbol{d}^{\top}\boldsymbol{W}\boldsymbol{d} = 2 > 0.$$

图 19.13说明了这一点。沿着约束，Lagrange 函数向上弯；垂直于约束，它向下弯。但可行点不能离开约束线，所以垂直方向的负曲率不影响极小性。

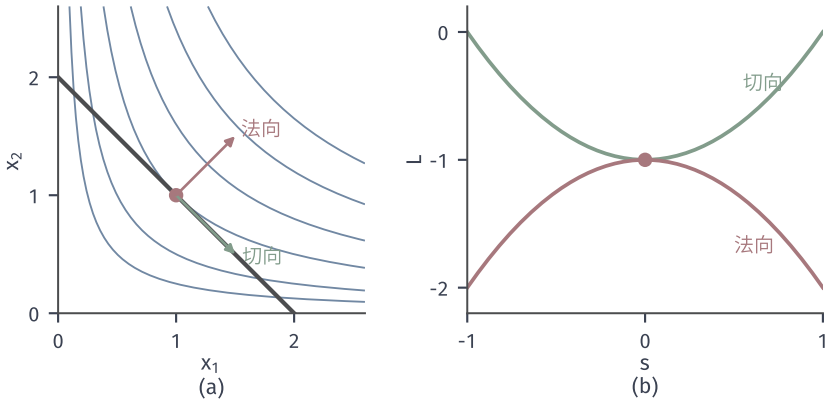


图 19.13 切空间上的正定性。(a) 蓝线是 x_1x_2 的等值线，深灰线是约束 $x_1+x_2=2$，红点是解，绿色箭头是切方向，红色箭头是法方向。(b) 取 $\nu=1$，Lagrange 函数沿切方向 $(1+s,1-s)$ 的值是 s^2-1（绿线），沿法方向 $(1+s,1+s)$ 的值是 $-1-s^2$（红线）。

Lagrange 函数对 $\boldsymbol{x}$ 的梯度是

$$\nabla_{\boldsymbol{x}}\mathcal{L}=(-x_2+\nu\theta,\,-x_1+\nu),$$

它对 θ 的偏导数是 $(\nu,0)$，而 $\partial h/\partial\theta = x_1$。在基准点，这些量都已知，式 (19.25)成为

$$\begin{bmatrix}0&-1&1\\-1&0&1\\1&1&0\end{bmatrix}\begin{bmatrix}x_1'\\x_2'\\\nu'\end{bmatrix}=-\begin{bmatrix}1\\0\\1\end{bmatrix}.$$

第二行给出 $\nu'=x_1'$，第一行给出 $x_2'=x_1'+1$，代入第三行 $x_1'+x_2'=-1$，得到

$$x_1'=-1,\qquad x_2'=0,\qquad \nu'=-1.$$

这与显式解在 $\theta=1$ 的导数一致：涨价时第一种投入减少，第二种投入不变。

如果把目标改成 $+x_1x_2$，KKT 矩阵仍然可逆，隐函数定理仍然给出同样的分支，但切方向的曲率变成 -2，这条分支上全是约束极大点。可逆只说明方程的解光滑，极小性要靠曲率的符号。

去掉条件会怎样 先去掉切空间正定性。考虑 $\min \frac{1}{2}x_2^2$，约束 $x_2-\theta=0$。约束梯度 $(0,1)$ 非零，但切方向 $(1,0)$ 上 $\boldsymbol{W}=\operatorname{diag}(0,1)$ 的曲率为零。此时 $\boldsymbol{K}$ 的第一行全为零，矩阵奇异。解集是整条直线 $\{(s,\theta):s\in\mathbb{R}\}$，“解的导数”没有确定的含义。

再去掉行满秩。考虑 $\min x$，约束 $x^2-\theta=0$。$\theta>0$ 时可行集是 $\{\pm\sqrt{\theta}\}$，最小点是 $x=-\sqrt{\theta}$，导数是 $-1/(2\sqrt{\theta})$，$\theta\downarrow 0$ 时趋于 $-\infty$。在 $\theta=0$ 处约

19.1 含参问题
19.2 最优值的变化
19.3 最优解的变化
19.3.1 无约束极小解
19.3.2 等式约束极小解
19.3.3 不等式约束极小解
19.4 分支变化
19.5 导数的计算与核验
19.6 本章小结

束梯度 $2x$ 为零，平稳条件 $1+2x\nu=0$ 在 $x=0$ 处没有解，KKT 条件本身就不成立。

19.3.3 不等式约束极小解

不等式比等式多了一件事：哪些约束起作用，可能随参数改变。本小节的思路是，只要局部上活动约束不变，就把它们当作等式，回到上一小节的情形。

需要的三个条件 考虑一般问题 (19.16)，设 $(\boldsymbol{x}_0,\boldsymbol{\lambda}_0,\boldsymbol{\nu}_0)$ 是 θ_0 处的 KKT 点，$A=\{i:g_i(\boldsymbol{x}_0,\theta_0)=0\}$ 是活动集，a 是其元素个数。这里用到第 17章的三个概念。

- 线性无关约束资格（LICQ）：活动不等式的梯度和全部等式的梯度线性无关。
- 严格互补：每个活动不等式的乘子都严格为正，$\lambda_{0,i}>0$（$i\in A$）。
- 二阶充分条件：$\boldsymbol{W}=\nabla^2_{\boldsymbol{xx}}\mathcal{L}$ 在临界锥上正定。严格互补成立时，临界锥就是子空间 $\ker\boldsymbol{J}$，其中 $\boldsymbol{J}$ 的行是活动不等式和全部等式的梯度。

把活动的不等式改写成等式，定义未知向量 $\boldsymbol{w}=(\boldsymbol{\lambda}_A,\boldsymbol{\nu})$，得到一个缩减的方程组

$$\boldsymbol{F}(\boldsymbol{x},\boldsymbol{w},\theta)=\begin{bmatrix}\nabla_{\boldsymbol{x}}\mathcal{L}\\ \boldsymbol{g}_A(\boldsymbol{x},\theta)\\ \boldsymbol{h}(\boldsymbol{x},\theta)\end{bmatrix}=\boldsymbol{0}. \tag{19.26}$$

活动约束的乘子和等式乘子是未知量，不活动约束的乘子取为零，不进入方程。

定理 19.13 不等式约束极小解的导数 设 f,g_i,h_j 在 $(\boldsymbol{x}_0,\theta_0)$ 的邻域内二阶连续可微，$(\boldsymbol{x}_0,\boldsymbol{\lambda}_0,\boldsymbol{\nu}_0)$ 是 KKT 点，LICQ、严格互补与二阶充分条件成立。则存在 θ_0 的邻域和唯一的连续可微映射 $(\boldsymbol{x}(\cdot),\boldsymbol{\lambda}(\cdot),\boldsymbol{\nu}(\cdot))$，它在基准处经过基准点，邻域内的每一点都是相应问题的 KKT 点，活动集恒为 A，$\boldsymbol{x}(\theta)$ 是严格局部极小点。导数 $\boldsymbol{D}_{\boldsymbol{x}}$、$\boldsymbol{D}_{\boldsymbol{w}}$ 满足

$$\begin{bmatrix}\boldsymbol{W} & \boldsymbol{J}^{\top}\\ \boldsymbol{J} & \boldsymbol{0}\end{bmatrix}\begin{bmatrix}\boldsymbol{D}_{\boldsymbol{x}}\\ \boldsymbol{D}_{\boldsymbol{w}}\end{bmatrix}=-\begin{bmatrix}\nabla^2_{\boldsymbol{x}\theta}\mathcal{L}\\ \boldsymbol{D}_{\theta}(\boldsymbol{g}_A,\boldsymbol{h})\end{bmatrix}. \tag{19.27}$$

证明 LICQ 就是 $\boldsymbol{J}$ 行满秩，严格互补使二阶充分条件成为 $\boldsymbol{W}$ 在 $\ker \boldsymbol{J}$ 上正定。由引理 19.11，矩阵 $\boldsymbol{K}$ 可逆，隐函数定理给出式 (19.26)的连续可微解 $(\boldsymbol{x}(\theta), \boldsymbol{w}(\theta))$，求导得到式 (19.27)。

下面验证这个解确实是完整问题的 KKT 点。不活动约束满足 $g_i(\boldsymbol{x}_0, \theta_0) < 0$，由连续性，附近仍有 $g_i(\boldsymbol{x}(\theta), \theta) < 0$，把它们的乘子取为零。活动约束的乘子满足 $\lambda_{0,i} > 0$，由连续性，附近仍有 $\lambda_i(\theta) > 0$。于是可行性、乘子符号和互补松弛全部成立，活动集仍是 A，且严格互补仍成立。

与定理 19.12相同的连续性论证说明，$\boldsymbol{J}$ 行满秩和 $\ker \boldsymbol{J}$ 上的正定性在附近保持，二阶充分条件推出 $\boldsymbol{x}(\theta)$ 是严格局部极小点。

最后看唯一性。若完整问题另有 KKT 点靠近基准点，不活动约束仍严格满足，其乘子必为零；活动约束的乘子靠近正数 $\lambda_{0,i}$，也为正，由互补松弛这些约束取等号。这个点于是满足式 (19.26)，由隐函数定理的唯一性，它就在分支上。 ■

图 19.14画出式 (19.27)的结构。系数矩阵只由基准点的量决定，q 个参数对应 q 列右端。

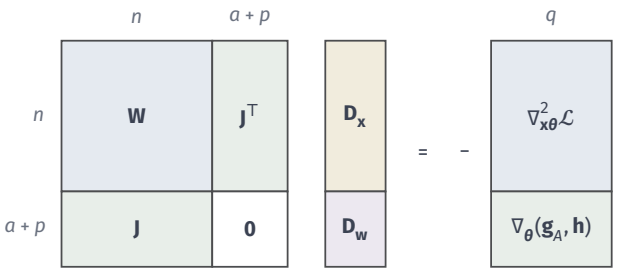


图 19.14 式 (19.27)的分块结构。系数矩阵的阶数是 $n + a + p$，其中 a 是活动不等式个数，p 是等式个数。$\boldsymbol{D}_x$ 与 $\boldsymbol{D}_w$ 是待求的 Jacobian 矩阵，右端共 q 列，每列对应一个参数。不活动约束不出现在这个方程组中。

预算例的两个活动集 取 $\tau = 2$。活动集是 $\{1\}$，方程组与第 19.3.2节的预算线例子完全相同，因为只有预算在起作用：

$$x_1' = x_2' = \frac{1}{2}, \qquad \lambda_1' = -\frac{1}{2}.$$

取 $\tau = 0.5$。解是 $(0.5, 0)$，乘子是 $\lambda_1 = 3/2$，$\lambda_3 = 1/2$，活动集是 $\{1, 3\}$。此时 $\boldsymbol{W} = \boldsymbol{I}$，活动约束的梯度组成

$$\boldsymbol{J} = \begin{bmatrix} 1 & 1 \\ 0 & -1 \end{bmatrix}, \qquad \frac{\partial}{\partial \tau} \begin{bmatrix} g_1 \\ g_3 \end{bmatrix} = \begin{bmatrix} -1 \\ 0 \end{bmatrix}.$$

$\ker \boldsymbol{J}$ 只含零向量，切空间的正定性自动成立。式 (19.27)的四行分别是

$$x_1' + \lambda_1' = 0, \quad x_2' + \lambda_1' - \lambda_3' = 0, \quad x_1' + x_2' = 1, \quad -x_2' = 0.$$

依次解出

$$x_2' = 0, \qquad x_1' = 1, \qquad \lambda_1' = -1, \qquad \lambda_3' = -1.$$

这时增加的预算全部给第一种投入，因为 x_2 被边界挡在零上。

严格互补和余量给出窗口 严格互补与不活动约束的严格余量在定理中起同一种作用：它们留出一段余地，让参数小幅变化时符号条件不被破坏。这段余地有多大，可以用导数估计。

在 $\tau = 2$ 处，三个要保持为正的量分别是不活动约束的余量 x_1、x_2 和活动约束的乘子 λ_1。沿分支它们是

$$x_1 = \frac{\tau + 1}{2}, \qquad x_2 = \frac{\tau - 1}{2}, \qquad \lambda_1 = \frac{3 - \tau}{2}.$$

第一个到达零的是 $x_2\,(\tau = 1)$ 和 $\lambda_1\,(\tau = 3)$，分支的有效窗口是 $1 < \tau < 3$，见图 19.15。窗口的一端是不活动约束变成活动，另一端是活动约束不再起作用。

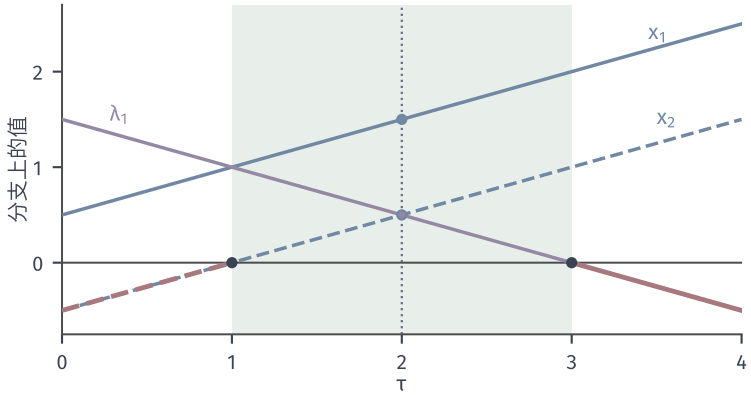


图 19.15 活动集 {1} 的分支把公式延拓到窗口之外。蓝色实线与虚线是不活动约束的余量 x_1、x_2，紫线是乘子 λ_1，绿色区域是三者都为正的窗口 $1 < \tau < 3$。红色部分是符号条件被破坏之处：$\tau < 1$ 时 $x_2 < 0$ 不可行，$\tau > 3$ 时 $\lambda_1 < 0$ 不满足 KKT 条件。

这些条件只是充分的 定理的三个条件对解可微是充分条件，下面三个例子逐一说明它们都不是必要的。

严格互补不必要：考虑 $\min \frac{1}{2}(x - \theta^2)^2$，约束 $x \geq 0$。解是 $x = \theta^2$，处处可微。而在 $\theta = 0$ 处，约束活动且乘子为零，严格互补不成立。

19.1 含参问题
19.2 最优值的变化
19.3 最优解的变化
19.4 分支变化
19.4.1 活动集改变
19.4.2 全局最优解切换
19.4.3 退化与变化尺度
19.5 导数的计算与核验
19.6 本章小结

LICQ 不必要：约束写两遍 $\theta - x \le 0$，目标取 $\min x$。解 $x = \theta$ 处处可微，两条活动约束的梯度相同，LICQ 不成立，乘子也不唯一。

二阶充分条件不必要：考虑 $\min x^4/4 - \theta^3 x$，驻点方程 $x^3 = \theta^3$ 给出 $x = \theta$，处处可微。而在 $\theta = 0$ 处 Hessian 等于零。

反过来，这些条件被破坏时，导数常常确实失效，下一节拆开具体的失效方式。定理不能用来断言“条件不成立，所以不可微”。

19.4 分支变化

上一节的局部导数有前提。前提不成立时，导数为什么会失效，失效的方式有什么不同？本节用三个能够手算的例子回答。活动集改变时，可用的方程变了。全局最优解切换时，所选的分支变了。方程退化时，线性方程不再可逆。三种情况的数学原因不同，都不是某个算法的不稳定。

19.4.1 活动集改变

分段解出预算例 把预算例按活动集分成三段，每段都用 KKT 条件解出。

当 $\tau > 3$ 时，理想点 $(2,1)$ 满足 $x_1 + x_2 \le \tau$，全部约束不起作用：

$$\boldsymbol{x}^\star = (2,1), \qquad \boldsymbol{\lambda} = \mathbf{0}, \qquad V(\tau) = 0.$$

当 $1 < \tau < 3$ 时，只有预算起作用。平稳条件是 $x_1 - 2 + \lambda_1 = 0$、$x_2 - 1 + \lambda_1 = 0$，代入 $x_1 + x_2 = \tau$，得到 $3 - 2\lambda_1 = \tau$，于是

$$\lambda_1 = \frac{3-\tau}{2}, \qquad \boldsymbol{x}^\star = \Big(\frac{\tau+1}{2}, \frac{\tau-1}{2}\Big).$$

两个坐标与乘子在这段都是正的。目标值是 λ_1^2，即 $V(\tau) = (3-\tau)^2/4$。

当 $0 < \tau < 1$ 时，预算和 $x_2 \ge 0$ 起作用，$\boldsymbol{x}^\star = (\tau, 0)$。平稳条件的两个分量是 $x_1 - 2 + \lambda_1 = 0$ 和 $x_2 - 1 + \lambda_1 - \lambda_3 = 0$，由此解出

$$\lambda_1 = 2 - \tau, \qquad \lambda_3 = 1 - \tau.$$

两者都为正。目标值是

$$V(\tau) = \frac{1}{2}(2-\tau)^2 + \frac{1}{2}.$$

区间	$\boldsymbol{x}^\star(\tau)$	(λ_1, λ_3)	$V'(\tau)$
$0 < \tau < 1$	$(\tau,\ 0)$	$(2-\tau,\ 1-\tau)$	$\tau - 2$
$1 < \tau < 3$	$\left(\frac{\tau+1}{2},\ \frac{\tau-1}{2}\right)$	$\left(\frac{3-\tau}{2},\ 0\right)$	$\frac{\tau-3}{2}$
$\tau > 3$	$(2,\ 1)$	$(0,\ 0)$	0

表 19.2 预算例的三段解，λ_2 在所有区间都等于零。每一段内 $V'(\tau) = -\lambda_1$，这正是乘子的边际解释。

连接点上发生了什么 图 19.16画出解在平面上的路径，图 19.17画出各个量随 τ 的变化。解的路径是一条折线，在 $\tau = 1$ 与 $\tau = 3$ 处转弯。

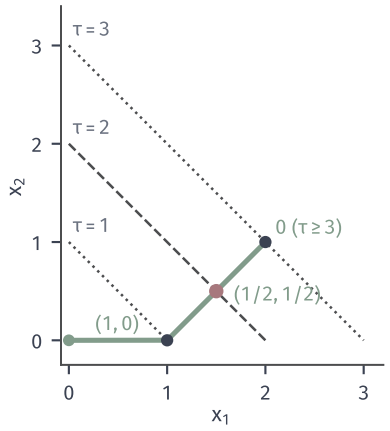


图 19.16 最优解 $\boldsymbol{x}^\star(\tau)$ 在平面上的路径（绿线）。虚线与点线是几条预算线，黑点是活动集改变的位置，红点是 $\tau = 2$ 的解。绿色文字是各段上解对 τ 的导数：第一段 $(1, 0)$，第二段 $(1/2, 1/2)$，$\tau \geq 3$ 时为零。

$\tau = 1$ 处，$x_2 \geq 0$ 刚要失去作用，$\lambda_3 = 0$。$\tau = 3$ 处，预算刚要失去作用，$\lambda_1 = 0$。两处都有活动约束的乘子等于零，严格互补恰好在连接点失败。

解在连接点连续但不可微。$\tau = 1$ 处的左导数和右导数分别是

$$\boldsymbol{x}'(1^-) = (1, 0), \qquad \boldsymbol{x}'(1^+) = \left(\frac{1}{2}, \frac{1}{2}\right).$$

值函数却不一样。两段的 V' 在 $\tau = 1$ 处都等于 -1，在 $\tau = 3$ 处都等于 0，所以 V 在连接点可微，只是二阶导数有跳跃。原因是 $V' = -\lambda_1$，而 λ_1 连续穿过连接点：进入或离开活动集的约束，它的乘子在那里恰好是零，不造成 λ_1 的跳变。

19.1 含参问题
19.2 最优值的变化
19.3 最优解的变化
19.4 分支变化
19.4.1 活动集改变
19.4.2 全局最优解切换
19.4.3 退化与变化尺度
19.5 导数的计算与核验
19.6 本章小结

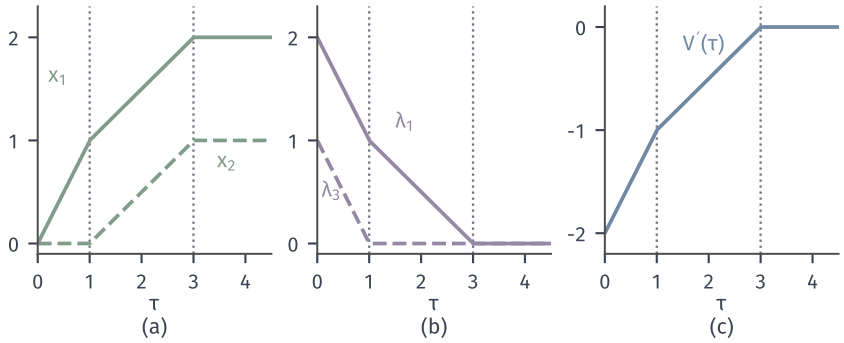


图 19.17 预算例各量随 τ 的变化，灰色点线标出 $\tau = 1, 3$。(a) 解的两个分量（实线 x_1，虚线 x_2）在连接点转折。(b) 乘子 λ_1（实线）、λ_3（虚线）连续，但斜率改变。(c) $V'(\tau)$ 连续，说明 V 在连接点仍然可微。

固定活动集的公式不能外推 公式必须限定在它的区间内使用。把活动集 $\{1\}$ 的公式用到 $\tau = 0.5$，得到 $x_2 = -0.25$，不可行。用到 $\tau = 4$，得到 $\lambda_1 = -1/2$，乘子符号错误。这两种错误恰好给出判别方法：预测的不活动约束是否越界，预测的乘子是否变负。

连接点上只有单侧的导数。向哪一侧走，就要换用那一侧的活动集重新写方程，上面的 $\boldsymbol{x}'(1^-)$ 和 $\boldsymbol{x}'(1^+)$ 正是这样得到的。

19.4.2 全局最优解切换

两个候选的比较 活动集改变时解连续地走过连接点。全局最优解还可能在两个相距很远的候选之间跳动。最简单的例子是在两点集合上选最小：

$$\min_{x\in\{-1,1\}} \theta x. \tag{19.28}$$

把两个候选分别看成两条分支：

$$x = 1: \quad v_1(\theta) = \theta, \qquad\qquad x = -1: \quad v_2(\theta) = -\theta.$$

每条分支上解都是常数，$\boldsymbol{x}' = 0$，值是线性函数，两者都光滑。

全局最优值取两条分支的较小者，最优解集合随 θ 的符号改变：

$$V(\theta) = -|\theta|, \qquad \boldsymbol{S}(\theta) = \begin{cases} \{1\}, & \theta < 0, \\ \{-1, 1\}, & \theta = 0, \\ \{-1\}, & \theta > 0. \end{cases} \tag{19.29}$$

图 19.18分别显示了三件事。每条分支在 $\theta = 0$ 处都很光滑。全局值在 $\theta = 0$ 处不可微。解集合在 $\theta = 0$ 处从一个点变成两个点，再变回另一个点，选出的解不连续。

19.1　含参问题
19.2　最优值的变化
19.3　最优解的变化
19.4　分支变化
19.4.1　活动集改变
19.4.2　全局最优解切换
19.4.3　退化与变化尺度
19.5　导数的计算与核验
19.6　本章小结

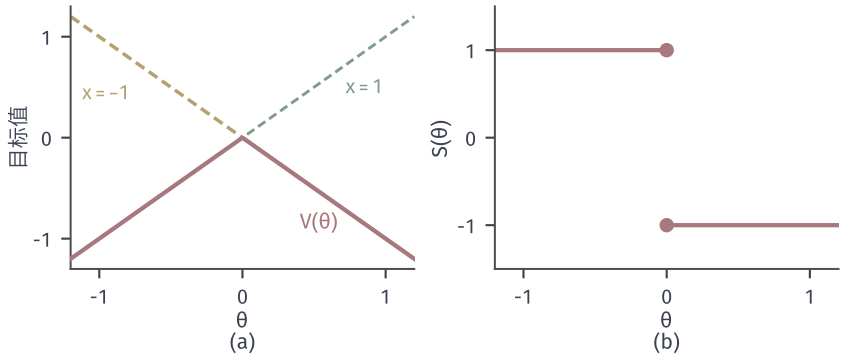


图 19.18　在 $\{-1,1\}$ 上最小化 θx。(a) 绿色虚线是 $x=1$ 分支的值，黄色虚线是 $x=-1$ 分支的值，红线是全局最优值 $-|\theta|$。(b) 全局最优解集合，$\theta=0$ 处两个点都最优，解在此跳跃。

三个对象分别的结论　定理 19.6在这里成立：$\boldsymbol{C}=\{-1,1\}$ 是紧集，$\partial f/\partial\theta = x$ 连续。在 $\theta=0$ 处，它给出

$$V'(0;d)=\min_{x\in\{-1,1\}} xd=-|d|,$$

这与 $V(\theta)=-|\theta|$ 一致。

把一条分支的导数推广成全局公式是常见的错误。$x=1$ 分支的导数在 $\theta>0$ 时仍然是 1，但 $\theta>0$ 时全局最优解已经是 -1，全局值的导数是 -1。第 19.1节的双谷目标在连续变量上重现了同样的现象：每个谷底都有光滑的分支，全局最优解在 $\theta=0$ 处跳到另一个谷底。在双谷的右侧分支上，驻点方程 $4x^3-4x+\theta=0$ 对 x 的导数在 $x=1$ 处是 8，隐函数定理给出

$$x'(0)=-\frac{1}{8}.$$

这个导数描述的是右侧谷底的移动，与全局最优解在 $\theta=0$ 处的跳跃无关。

19.4.3　退化与变化尺度

前两种失效换了方程或换了分支。第三种失效中方程和分支都没有换，解甚至唯一，只是线性化之后的方程退化了。

唯一解也可能没有有限导数　考虑

$$\min_{x\in\mathbb{R}} \frac{1}{4}x^4-\theta x. \tag{19.30}$$

对每个 θ，目标严格凸且强制，最优解唯一。驻点方程 $x^3=\theta$ 给出

$$x^\star(\theta)=\theta^{1/3}.$$

$\theta = 0$ 处 $x^\star = 0$，Hessian$3x^2$ 等于零，隐函数定理的条件不成立。真实导数是

$$\frac{\mathrm{d}x^\star}{\mathrm{d}\theta} = \frac{1}{3\theta^{2/3}} \quad (\theta \neq 0),$$

$\theta \to 0$ 时趋于 $+\infty$，解函数在 $\theta = 0$ 处有竖直的切线。参数变化 10^{-6}，解移动 10^{-2}，一万倍的放大，见图 19.19(b)。

值函数却没有这个问题。把解代入，

$$V(\theta) = \frac{1}{4}\theta^{4/3} - \theta^{4/3} = -\frac{3}{4}|\theta|^{4/3},$$

并且 $V'(\theta) = -\theta^{1/3}$，在 $\theta = 0$ 处等于零。这正是包络关系：$\partial f/\partial\theta = -x$，只需知道解的位置，不需要它的导数。再一次看到，值比解更稳定。

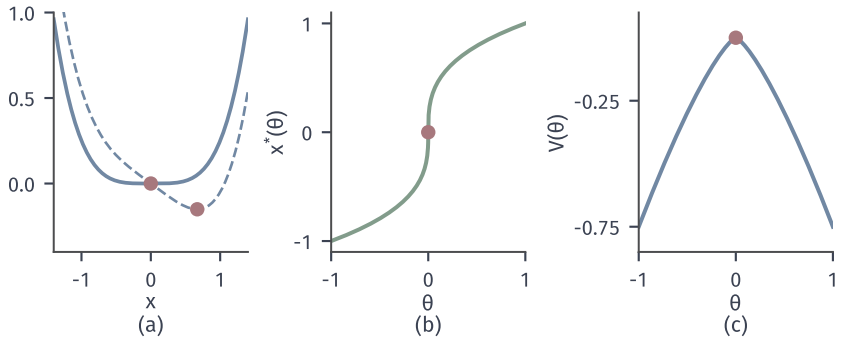


图 19.19 退化的唯一最优解。(a) 目标 $x^4/4 - \theta x$，实线 $\theta = 0$，虚线 $\theta = 0.3$，红点是最小点。$\theta = 0$ 时谷底二阶平坦。(b) 最优解 $\theta^{1/3}$ 在 $\theta = 0$ 处切线竖直。(c) 最优值 $-\frac{3}{4}|\theta|^{4/3}$ 在 $\theta = 0$ 处可微。

非退化时的放大倍数 矩阵 $\boldsymbol{K}$ 可逆但接近奇异时，导数存在却很大。记 $\boldsymbol{z} = (\boldsymbol{x}, \boldsymbol{w})$，$\boldsymbol{B} = \boldsymbol{D}_\theta \boldsymbol{F}$。由式 (19.27)，一阶变化满足 $\boldsymbol{K}\Delta\boldsymbol{z} = -\boldsymbol{B}\Delta\boldsymbol{\theta}$，因此

$$\|\Delta\boldsymbol{z}\|_2 \le \|\boldsymbol{K}^{-1}\|_2 \, \|\boldsymbol{B}\Delta\boldsymbol{\theta}\|_2. \tag{19.31}$$

$\|\boldsymbol{K}^{-1}\|_2$ 越大，同样的参数变化引起的解和乘子的变化可能越大。下面两种几何情形都会使它变大。

第一种是约束接近平行。取两条等式约束

$$x_1 + x_2 = \tau, \qquad x_1 + (1+\varepsilon)x_2 = 2 + \varepsilon.$$

解由它们的交点确定，$\tau = 2$ 时交点是 $(1, 1)$。解线性方程，得到

$$\boldsymbol{x}'(\tau) = \Big(\frac{1+\varepsilon}{\varepsilon}, -\frac{1}{\varepsilon}\Big).$$

$\varepsilon = 0.25$ 时导数是 $(5, -4)$，$\varepsilon = 0.01$ 时是 $(101, -100)$。约束梯度仍然线性无关，LICQ 成立，只是接近失效。图 19.20(a) 里，预算线只平移一点，交点却沿着两条线滑过很长的距离。

第二种是碗的底部很平。考虑二次目标

$$f(\boldsymbol{x}, \boldsymbol{b}) = \frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{H}\boldsymbol{x} - \boldsymbol{b}^{\top}\boldsymbol{x}, \qquad \boldsymbol{H} = \operatorname{diag}(1, 0.1).$$

把 b_2 从 0.1 改为 0.2，解从 $(1,1)$ 移到 $(1,2)$。参数只变化 0.1，解移动了 1，放大倍数是曲率的倒数，即 10。

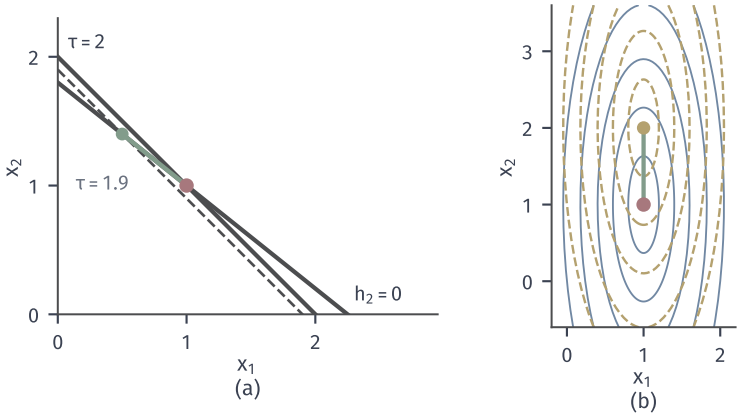


图 19.20 两种放大机制。(a) $\varepsilon = 0.25$ 的两条等式约束，预算线从实线 $\tau = 2$ 平移到虚线 $\tau = 1.9$，交点沿绿色线段从红点移到绿点，距离约是平移量的 6.4 倍。(b) $\boldsymbol{H} = \operatorname{diag}(1, 0.1)$ 的目标等高线，蓝色实线是 $b_2 = 0.1$，黄色虚线是 $b_2 = 0.2$，最小点沿绿色线段从红点移到黄点。

固有敏感性与数值误差 上面的放大是问题的性质，与用什么算法无关。这里有两种不同的误差，需要分开。

	固有敏感性	数值误差
比较	不同参数的精确解	同一问题的计算解与精确解
度量	$\boldsymbol{Dz}$ 的大小	残差、舍入与条件数
改善	改变模型或数据	改进算法与精度

表 19.3 固有敏感性与数值误差的比较。两者都可能与 $\boldsymbol{K}$ 的病态有关，但回答不同的问题。

19.1 含参问题
19.2 最优值的变化
19.3 最优解的变化
19.4 分支变化
19.5 导数的计算与核验
19.6 本章小结

矩阵的条件数大，并不一定说明解对参数敏感。把预算例中预算约束整体乘以 $s>0$，写成 $s(x_1+x_2-\tau)\le 0$。这是同一个约束，解不变，解对 τ 的导数也不变，乘子则变成原来的 $1/s$。相应的 KKT 矩阵是

$$\boldsymbol{K}_s=\begin{bmatrix}1&0&s\\0&1&s\\s&s&0\end{bmatrix}.$$

$s=1$ 时条件数是 2。$s=1000$ 时条件数约为 1415，而 $\boldsymbol{x}'(\tau)$ 仍然是 $(1/2,1/2)$。这里的条件数变大只反映约束的书写尺度，解的敏感性没有任何变化。

解读式 (19.31)之前，应该先把变量和约束调整到量纲合理的尺度，计算时也应该作相应的平衡处理。只有这样，$\boldsymbol{K}$ 的病态才能反映问题真实的敏感性。

19.5 导数的计算与核验

局部导数的公式已经有了，怎样计算它们，又怎样确认算出的结果可信？

主要思想：一次分解，多个右端 式 (19.27)的系数矩阵 $\boldsymbol{K}$ 只依赖基准点，右端 $\boldsymbol{B}$ 的每一列对应一个参数。记 $N=n+a+p$，把待求的两块 Jacobian 矩阵合写成

$$\boldsymbol{Z}=\begin{bmatrix}\boldsymbol{D}_{\boldsymbol{x}}\\ \boldsymbol{D}_{\boldsymbol{w}}\end{bmatrix}\in\mathbb{R}^{N\times q}.$$

需要解的是

$$\boldsymbol{K}\boldsymbol{Z}=-\boldsymbol{B}. \tag{19.32}$$

这相当于同一个矩阵配上 q 个右端，只需分解一次，然后对每一列回代。不需要对每个参数重解一次原来的非线性问题。$\boldsymbol{K}$ 对称而不定，通常用带主元选取的 $\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\top}$ 分解，分解的做法可参考卷二第 12 章“线性方程的直接求解”。

分解还可以顺便检查极小性。$\boldsymbol{J}$ 行满秩时，$\boldsymbol{W}$ 在 $\ker\boldsymbol{J}$ 上正定，当且仅当 $\boldsymbol{K}$ 恰有 n 个正特征值、$a+p$ 个负特征值、没有零特征值。这称为**惯性**（inertia）判别，证明可查阅[2]。$\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\top}$ 分解的 $\boldsymbol{D}$ 与 $\boldsymbol{K}$ 合同，读出 $\boldsymbol{D}$ 的正负特征值个数，就得到惯性，不必另算。

[2] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

主要思想：只要一个输出时用伴随 有时我们并不需要整个 $\boldsymbol{D}_{\boldsymbol{x}}$，只要一个标量输出 $\phi(\boldsymbol{x}(\theta))$ 对 q 个参数的梯度。这时梯度是

$$\nabla_{\theta}\phi=\boldsymbol{D}_{\boldsymbol{x}}^{\top}\boldsymbol{c},\qquad \boldsymbol{c}=\nabla\phi(\boldsymbol{x}).$$

代入式 (19.32)，并在 $\boldsymbol{c}$ 后面补零以匹配维数，就是

$$\nabla_\theta \phi = -\boldsymbol{B}^\top \boldsymbol{r}, \qquad \boldsymbol{K}\boldsymbol{r} = \begin{bmatrix} \boldsymbol{c} \\ \boldsymbol{0} \end{bmatrix}. \tag{19.33}$$

这里用到 $\boldsymbol{K}$ 对称。式 (19.33)只解一个线性方程，与参数个数无关。这种做法称为**伴随法** (adjoint method)。两种算法的差别只是矩阵乘积 $\boldsymbol{c}^\top \boldsymbol{K}^{-1}\boldsymbol{B}$ 的结合顺序不同，见图 19.21。

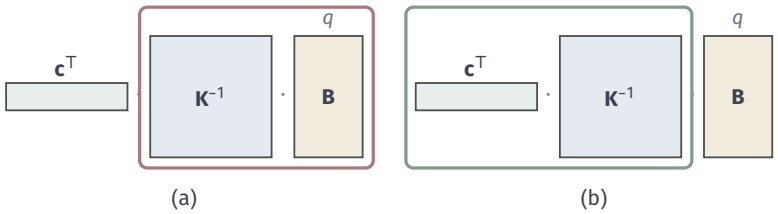


图 19.21 同一乘积 $\boldsymbol{c}^\top \boldsymbol{K}^{-1}\boldsymbol{B}$ 的两种结合顺序。(a) 先算红框内的 $\boldsymbol{K}^{-1}\boldsymbol{B}$，每个参数一个右端，得到全部的 $\boldsymbol{D}_{\boldsymbol{x}}$。(b) 先算绿框内的 $\boldsymbol{c}^\top \boldsymbol{K}^{-1}$，只有一个右端，得到单个输出对全部参数的梯度。

表 19.4比较各种做法的成本，规模变量为 N 与 q，运算量只计首项。重新求解一列的成本指做一次完整的 $\boldsymbol{K}$ 分解，实际的非线性重解通常更贵。$\boldsymbol{K}$ 稀疏时，分解成本由消元产生的填充决定，回代成本是 $\boldsymbol{L}$ 的非零元个数的两倍，表中的立方、平方相应缩小，分解一次多次回代的比例关系不变。

做法	稠密运算量	得到什么
每个参数重解	$qN^3/3$	全部 $\boldsymbol{D}_{\boldsymbol{x}}$
一次分解，q 次回代	$N^3/3 + 2qN^2$	全部 $\boldsymbol{D}_{\boldsymbol{x}}$ 和 $\boldsymbol{D}_{\boldsymbol{w}}$
伴随法	$N^3/3 + 2N^2$	一个输出的梯度

表 19.4 计算解对参数导数的稠密运算量，$N = n + a + p$。分解的复用要求活动集不变。伴随法的结果再乘 $\boldsymbol{B}^\top$ 需要的运算量与 $\boldsymbol{B}$ 的非零元个数成正比。

计算过程 下面把全过程用在一个小例子上。预算例中同时考虑两个参数，预算 τ 和理想点的横坐标偏移 θ，基准是 $(\tau, \theta) = (2, 0)$，目标是

$$f(\boldsymbol{x}, \theta) = \frac{1}{2}(x_1 - 2 - \theta)^2 + \frac{1}{2}(x_2 - 1)^2.$$

变量

- 基准解 $\boldsymbol{x} \in \mathbb{R}^n$，活动乘子与等式乘子合写成 $\boldsymbol{w} \in \mathbb{R}^{a+p}$。
- 系数矩阵 $\boldsymbol{K} \in \mathbb{R}^{N\times N}$，右端 $\boldsymbol{B} \in \mathbb{R}^{N\times q}$，$N = n + a + p$。
- 输出 $\boldsymbol{Z}$，形状是 $N \times q$，含 $\boldsymbol{D}_{\boldsymbol{x}}$ 与 $\boldsymbol{D}_{\boldsymbol{w}}$ 两块。
- 每个不活动约束的余量，每个活动约束的乘子，它们决定分支的有效范围。

初始化 先把基准问题求解到足够高的精度，读出解和乘子，再分出活动约束。

例中 $n = 2$，$a = 1$，$p = 0$，$q = 2$。基准解和乘子是

$$\boldsymbol{x} = \begin{bmatrix} 3/2 \\ 1/2 \end{bmatrix}, \qquad \lambda_1 = \frac{1}{2}, \qquad A = \{1\}.$$

计算步骤

1. 组装 $\boldsymbol{K}$ 和 $\boldsymbol{B}$，公式见式 (19.27)。

   例中 Lagrange 函数的梯度和活动约束分别是

   $$\nabla_{\boldsymbol{x}} \mathcal{L} = (x_1 - 2 - \theta + \lambda_1,\; x_2 - 1 + \lambda_1), \quad g_1 = x_1 + x_2 - \tau,$$

   对 $\boldsymbol{x}$、λ_1 和 (τ, θ) 分别求偏导，得到

   $$\boldsymbol{K} = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 0 \end{bmatrix}, \qquad \boldsymbol{B} = \begin{bmatrix} 0 & -1 \\ 0 & 0 \\ -1 & 0 \end{bmatrix}.$$

   $\boldsymbol{B}$ 的第一列对应 τ，第二列对应 θ。

2. 分解 $\boldsymbol{K} = \boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\top}$，并由 $\boldsymbol{D}$ 的符号检查惯性。

   例中不需要主元交换，消元得到

   $$\boldsymbol{L} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix}, \qquad \boldsymbol{D} = \operatorname{diag}(1, 1, -2).$$

   $\boldsymbol{D}$ 有两个正数和一个负数，与 $n = 2$，$a = 1$ 相符，这个解是局部极小点。

3. 对 $\boldsymbol{B}$ 的每一列回代，得到 $\boldsymbol{Z}$ 的相应列，公式见式 (19.32)。

例中 τ 列的右端是 $(0,0,1)^{\top}$。依次解 $\boldsymbol{L}\boldsymbol{y} = (0,0,1)^{\top}$、$\boldsymbol{D}\boldsymbol{y}' = \boldsymbol{y}$、$\boldsymbol{L}^{\top}\boldsymbol{z} = \boldsymbol{y}'$，中间结果和最终结果是

$$\boldsymbol{y} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}, \quad \boldsymbol{y}' = \begin{bmatrix} 0 \\ 0 \\ -1/2 \end{bmatrix}, \quad \boldsymbol{z} = \begin{bmatrix} 1/2 \\ 1/2 \\ -1/2 \end{bmatrix}.$$

θ 列的右端是 $(1,0,0)^{\top}$，同样回代，得到

$$\boldsymbol{y} = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}, \quad \boldsymbol{y}' = \begin{bmatrix} 1 \\ 0 \\ 1/2 \end{bmatrix}, \quad \boldsymbol{z} = \begin{bmatrix} 1/2 \\ -1/2 \\ 1/2 \end{bmatrix}.$$

4. 用余量和乘子确定有效范围。把导数代入，对方向 $(\Delta\tau, \Delta\theta)$ 写出需要保持为正的量。

   例中这三个量分别是

$$\begin{aligned} \lambda_1 &= \frac{1}{2} - \frac{1}{2}\Delta\tau + \frac{1}{2}\Delta\theta, \\ x_1 &= \frac{3}{2} + \frac{1}{2}\Delta\tau + \frac{1}{2}\Delta\theta, \\ x_2 &= \frac{1}{2} + \frac{1}{2}\Delta\tau - \frac{1}{2}\Delta\theta. \end{aligned}$$

   它们都大于零的区域是参数平面上的一个多面体，图 19.22中绿色的带形就是这个区域在图中范围内的部分。

5. 给出预测，并用小幅参数重求解核验：预测的活动集是否保持，预测的解与重解的结果相差多少。

   例中取 $(\Delta\tau, \Delta\theta) = (0.2, 0.1)$，三个量都为正，预测和重解都是

$$\boldsymbol{x} = (1.65,\ 0.55), \qquad \lambda_1 = 0.45.$$

   问题在这个活动集上是二次的，所以预测是精确的。若取 $(\Delta\tau, \Delta\theta) = (-1.5, 0)$，预测给出 $x_2 = -1/4 < 0$，这说明活动集已经改变，需要换到活动集 $\{1,3\}$ 重新计算，真实解是 $(0.5, 0)$。

   整个计算是一次完成的，没有迭代，到步骤五结束。最终得到

$$\boldsymbol{D}_{\boldsymbol{x}} = \begin{bmatrix} 1/2 & 1/2 \\ 1/2 & -1/2 \end{bmatrix}, \qquad \boldsymbol{D}_{\lambda_1} = \begin{bmatrix} -1/2 & 1/2 \end{bmatrix}.$$

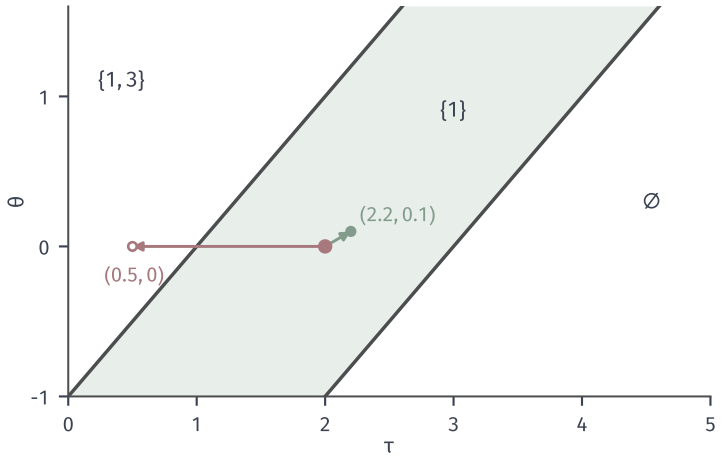


图 19.22　参数平面 (τ,θ) 上的活动集区域。两条深灰线是 $\tau=1+\theta$ 和 $\tau=3+\theta$，它们划分出活动集 $\{1,3\}$、$\{1\}$ 和 $\varnothing$。红点是基准 $(2,0)$，绿色箭头走到同一区域内的 $(2.2,0.1)$，一阶预测有效；红色箭头越过边界到 $(0.5,0)$，一阶预测失效。

伴随法在这个例子上也可以手算。设只关心输出 $\phi=x_2$，$\boldsymbol{c}=(0,1)^{\top}$。由式 (19.33)，解 $\boldsymbol{K}\boldsymbol{r}=(0,1,0)^{\top}$，得到 $\boldsymbol{r}=(-1/2,1/2,1/2)^{\top}$，再求

$$\nabla_{(\tau,\theta)}x_2=-\boldsymbol{B}^{\top}\boldsymbol{r}=\begin{bmatrix}1/2\\-1/2\end{bmatrix}.$$

这正是 $\boldsymbol{D}_{\boldsymbol{x}}$ 的第二行，一次回代就得到了两个参数的结果。

算法分析：误差的三个来源　隐式导数的公式对应精确的最优性方程。实际算出的导数还带有三种误差，它们的性质不同。

第一种是近似解带来的误差。基准解只解到 $\tilde{\boldsymbol{x}}$，$\boldsymbol{K}$ 和 $\boldsymbol{B}$ 都在 $\tilde{\boldsymbol{x}}$ 处组装，导数的误差与解的误差成正比，比例系数由 $\boldsymbol{K}^{-1}$ 和二阶导数的变化率决定。参数只出现在线性项时 $\boldsymbol{B}$ 不依赖于 $\boldsymbol{x}$，二次目标下这项误差为零。

第二种是有限差分的误差。用重解来核验导数时，常用中心差分

$$\frac{\boldsymbol{x}(\theta+h\boldsymbol{d})-\boldsymbol{x}(\theta-h\boldsymbol{d})}{2h},$$

截断误差是 $O(h^2)$。若每次重解的误差是 ε，差分会放大成 $O(\varepsilon/h)$。两项相加的误差在 $h\sim\varepsilon^{1/3}$ 时最小，约为 $\varepsilon^{2/3}$。

第三种是算法展开的误差。把迭代算法写成关于 θ 的函数，对 T 步迭代逐步求导，得到的是 $\boldsymbol{x}^{(T)}$ 的导数，而不是 $\boldsymbol{x}^{\star}$ 的导数。以梯度下降为例，它的迭代是

$$\boldsymbol{x}^{(t+1)}=\boldsymbol{x}^{(t)}-\alpha\nabla_{\boldsymbol{x}}f(\boldsymbol{x}^{(t)},\theta),$$

导数的递推式是

$$\boldsymbol{D}^{(t+1)} = \big(\boldsymbol{I} - \alpha \nabla^2_{\boldsymbol{xx}} f\big)\boldsymbol{D}^{(t)} - \alpha \nabla^2_{\boldsymbol{x}\theta} f, \tag{19.34}$$

其中各导数都在 $(\boldsymbol{x}^{(t)}, \theta)$ 处取值。它的不动点正是式 (19.19)。

图 19.23用具体计算展示了这些误差。(a) 中，差分误差先随 h 减小而减小，到某个 h 之后反而增大，这个转折点随求解精度 ε 移动。(b) 在岭回归例子上比较了式 (19.34)的展开和在当前迭代点上计算的隐式导数：γ 改变了曲率，展开的误差多了一个随 t 增长的因子，所以比隐式导数略慢。

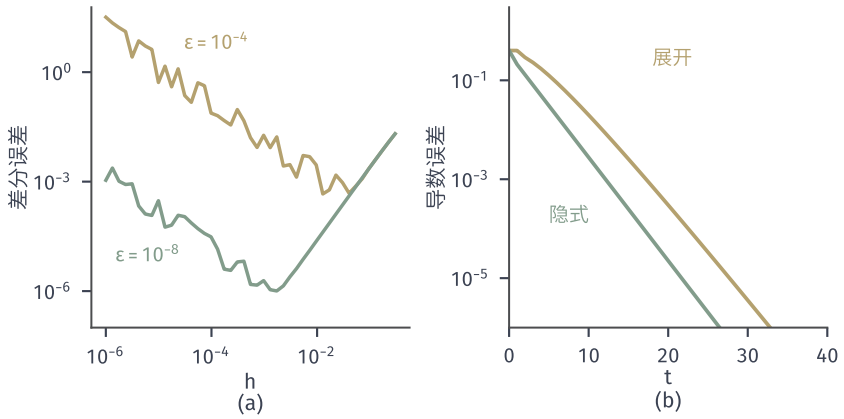


图 19.23 导数计算的误差。(a) 价格例 $\theta = 1$ 处 x_2 对 θ 的中心差分误差。每次重解用梯度下降到残差 ε，曲线取 40 次随机起点的中位数，黄线 $\varepsilon = 10^{-4}$，绿线 $\varepsilon = 10^{-8}$。(b) 岭回归例 $\gamma = 1$，步长 $\alpha = 1/L$，黄线是展开 t 步梯度下降得到的导数的误差，绿线是在 $\boldsymbol{x}^{(t)}$ 处计算隐式导数的误差。

算法分析：非二次问题的核验 第 19.2.4节的价格例不是二次的，一阶预测有误差，可以检验误差的阶。在 $\theta = 1$ 处，由 $\lambda'(1) = 1, x_1' = 1 - \lambda - \lambda'\theta = -1/2$，$x_2' = -\lambda' = -1$。与重解的结果比较，

$$h = 0.1: \quad \boldsymbol{x} = (1.4480,\ 0.4072), \quad \text{预测 } (1.45,\ 0.4),$$
$$h = 0.01: \quad \boldsymbol{x} = (1.49498,\ 0.49007), \quad \text{预测 } (1.495,\ 0.49).$$

误差分别约为 7.5×10^{-3} 和 7.9×10^{-5}，h 缩小十倍，误差缩小约一百倍，与二阶截断误差一致。

这个一致性只在活动集保持时成立。价格例的预算活动窗口是 $(\sqrt{5} - 1)/2 < \theta < 2$，$\theta > 2$ 时 $x_2 \geq 0$ 起作用。图 19.24(b) 中，h 接近 1 时误差开始偏离 h^2 的规律。检验时还应比较左右两侧的差商，它们不相等，或者差商不随 h 收敛，常常说明活动集正在改变。

19.1 含参问题
19.2 最优值的变化
19.3 最优解的变化
19.4 分支变化
19.5 导数的计算与核验
19.6 本章小结

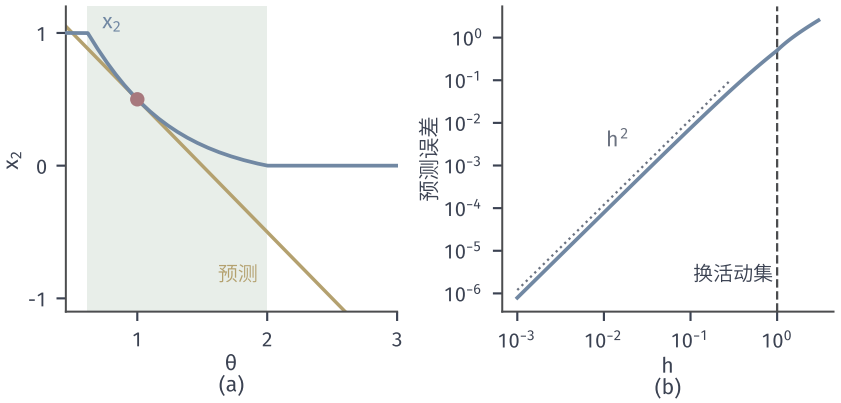


图 19.24 价格例的一阶预测。(a) $x_2(\theta)$ 的真实值（蓝线）和 $\theta = 1$ 处的线性预测（黄线），绿色区域是活动集保持的窗口。(b) 预测误差随 h 的变化（对数坐标，$\theta = 1 + h$），灰色点线是 h^2 的参考线，黑色虚线标出活动集改变的位置 $h = 1$。

19.6 本章小结

本章开头问：预算多一点，最优值变化多少，最优解往哪里移？回答这个问题，首先要说清比较的对象。最优值函数 V 是全局的，分支上的值 v 是局部的，解集合 $\boldsymbol{S}$ 可能为空或含多个点，只有选定分支或选解规则才有“解的导数”可谈。

最优值的变化有两类结论。约束右端扰动时，零间隙且乘子达到就给出对任意大小的扰动都成立的仿射下界，它不要求凸性，也不要求活动集不变。只有在 V 可微时，下界的斜率才等于实际导数；V 不可微时，全体最优乘子的相反数构成全部下界斜率，方向导数由其中最不利的一个决定。目标参数的变化由包络关系描述，一般含参约束下导数等于 Lagrange 函数显含参数的偏导。

最优解的移动由可逆的最优性方程描述。无约束时看 Hessian，等式约束时看 KKT 矩阵，只需在切空间上正定。不等式约束再加上 LICQ 与严格互补，活动约束便可当作等式处理。隐函数定理给出的是局部结论，定理的条件是充分而非必要的，方程的光滑解也要用二阶条件判定是否极小。

这些局部结论的失效方式彼此不同。活动集改变时，解连续但转折，值函数可能仍然可微。全局最优解切换时，每条分支都光滑，全局值出现折角，解发生跳跃。方程退化时，唯一的解也可能没有有限的导数，而值函数依然可微。判别时要看的是可用的方程、所选的分支和线性方程的可逆性分别是否变化。

计算时，同一次 $\boldsymbol{K}$ 分解可以服务多个右端，只要一个输出的梯度时伴随法只需一个右端。隐式导数对应精确的最优性方程，近似解、有限差分和有限次算法展开各自带有不同的误差，预测的有效性要靠余量、乘子符

号和小幅重解来核验。第 3章的固定基分析正是这一思路在线性规划上的实例，第 28章将继续用解映射的导数研究双层优化。

20.1 二次规划
20.1.1 凸二次规划
20.1.2 等式约束二次问题
20.1.3 非凸二次问题
20.2 锥规划
20.3 等价改写
20.4 半正定松弛
20.5 模型与求解方法
20.6 本章小结

第 20 章

二次规划与锥规划

设三次观测告诉我们 $x_1 + x_2 \approx 4$、$x_1 \approx 1$、$x_2 \approx 0$，而 x_1, x_2 又必须非负、总和不超过 2。这是带预算的最小二乘。换一个场合：要在两个圆盘的公共部分里找位置最低的点。再换一个：知道三个量两两之间的部分相关系数，要判断剩下的那个相关系数能取哪些值。

三件事看上去毫无关系，求解前却要回答同一个问题：目标和约束究竟是什么形状，能不能写成已有方法可以直接处理的形式？第一件事的目标是二次函数、约束是线性的；第二件事的约束是欧氏距离的上限；第三件事的约束是“某个对称矩阵的特征值非负”。这三种形状分别对应二次规划、二阶锥规划和半正定规划。

第 20.1节研究二次规划，看曲率和可行集怎样决定凸性、唯一性和计算方式。第 20.2节把线性规划的非负约束换成一般的闭凸锥，得到一种统一的模型和统一的对偶下界。

问题本身未必长成标准形式。第 20.3节研究怎样引入辅助变量而不改变问题，第 20.4节处理改不成凸问题的情形：放宽可行集，换来一个可以计算的下界。这两种操作的差别贯穿后半章，算出来的东西和原问题的关系也要分别核对。第 20.5节在同一个问题上比较各种写法的规模与代价。

20.1 二次规划

拿到一个二次目标、线性约束的问题，于是要问：怎样在动手求解之前，判断它是否凸、解是否唯一、哪些线性代数运算可以直接拿来用？

从带预算的最小二乘开始　回到章首的三次观测。把三条近似关系写成 $\boldsymbol{D}\boldsymbol{x} \approx \boldsymbol{r}$，其中

$$\boldsymbol{D} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}, \qquad \boldsymbol{r} = \begin{bmatrix} 4 \\ 1 \\ 0 \end{bmatrix}.$$

最小二乘的目标是 $\frac{1}{2}\|\boldsymbol{D}\boldsymbol{x}-\boldsymbol{r}\|_2^2$，约束是 $\boldsymbol{x}\ge\boldsymbol{0}$ 和预算 $x_1+x_2\le 2$。把这三条约束收集起来，就得到本节贯穿使用的问题。

展开平方，目标等于

$$\frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{D}^{\top}\boldsymbol{D}\boldsymbol{x}-\boldsymbol{r}^{\top}\boldsymbol{D}\boldsymbol{x}+\frac{1}{2}\|\boldsymbol{r}\|_2^2.$$

常数项不影响最优解。记 $\boldsymbol{Q}=\boldsymbol{D}^{\top}\boldsymbol{D}$、$\boldsymbol{q}=-\boldsymbol{D}^{\top}\boldsymbol{r}$，代入数据得到

$$\boldsymbol{Q}=\begin{bmatrix}2&1\\1&2\end{bmatrix},\qquad \boldsymbol{q}=\begin{bmatrix}-5\\-4\end{bmatrix},\qquad \frac{1}{2}\|\boldsymbol{r}\|_2^2=\frac{17}{2}. \tag{20.1}$$

于是目标是一个对称二次型加一个线性项，约束全是仿射的。

把这种形状抽象出来，就是下面的定义。为了不和最小二乘的 $\boldsymbol{D},\boldsymbol{r}$ 混淆，约束的系数用另外的字母。

定义 20.1　二次规划　设 $\boldsymbol{Q}\in\mathbb{R}^{n\times n}$ 对称，$\boldsymbol{q}\in\mathbb{R}^n$，$\boldsymbol{A}\in\mathbb{R}^{p\times n}$，$\boldsymbol{b}\in\mathbb{R}^p$，$\boldsymbol{G}\in\mathbb{R}^{m\times n}$，$\boldsymbol{h}\in\mathbb{R}^m$。问题

$$\begin{aligned}\min_{\boldsymbol{x}\in\mathbb{R}^n}\quad & f(\boldsymbol{x})=\frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{Q}\boldsymbol{x}+\boldsymbol{q}^{\top}\boldsymbol{x}\\ \text{s.t.}\quad & \boldsymbol{A}\boldsymbol{x}=\boldsymbol{b},\quad \boldsymbol{G}\boldsymbol{x}\le\boldsymbol{h}\end{aligned} \tag{20.2}$$

称为**二次规划**（quadratic program，QP）。不等式逐分量理解。可行集 $\boldsymbol{C}$ 是有限个闭半空间与超平面的交，即多面体。

例中 $p=0$，三条不等式对应

$$\boldsymbol{G}=\begin{bmatrix}1&1\\-1&0\\0&-1\end{bmatrix},\qquad \boldsymbol{h}=\begin{bmatrix}2\\0\\0\end{bmatrix}.$$

若把预算换成每个分量各自的上下限 $\boldsymbol{l}\le\boldsymbol{x}\le\boldsymbol{u}$，得到的是盒约束最小二乘，只是 $\boldsymbol{G},\boldsymbol{h}$ 的内容不同，目标部分完全一样。

拿到二次规划先问三件事　同一个形式 (20.2)覆盖了难度相差极大的问题，差别由下面三件事决定。

1. 曲率：$\boldsymbol{Q}$ 沿可以移动的方向是正、是零还是负？这决定问题是否凸、解是否唯一。
2. 可行集：有哪些等式和不等式，集合是否有界？这决定解会不会落在边界上、会不会跑到无穷远。

20.1 二次规划
20.1.1 凸二次规划
20.1.2 等式约束二次问题
20.1.3 非凸二次问题
20.2 锥规划
20.3 等价改写
20.4 半正定松弛
20.5 模型与求解方法
20.6 本章小结

3. 线性代数结构：$\boldsymbol{Q}$ 和约束矩阵是否稀疏、是否已有分解？这决定一次计算要花多少。

图 20.1画出例子。蓝色椭圆是目标的等高线，中心 $(2,1)$ 是不考虑约束时的最小二乘解。它的两个分量之和是 3，超出预算，所以留在三角形内的最好位置落在预算边上。在解 $\boldsymbol{x}^\star$ 处，负梯度仍然指向更低的椭圆中心，但沿这个方向走会离开可行集。

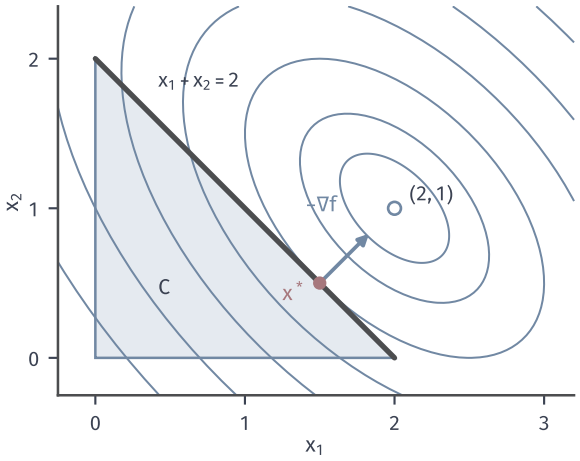


图 20.1　带预算的最小二乘问题。蓝色椭圆是目标 $\frac{1}{2}\|\boldsymbol{D}\boldsymbol{x}-\boldsymbol{r}\|_2^2$ 的等高线，空心点 $(2,1)$ 是无约束解。浅蓝三角形是可行集，深灰粗线是活动的预算约束，红点是解 $\boldsymbol{x}^\star=(3/2,1/2)$。蓝色箭头是按比例缩短的负梯度，它垂直于预算边。

20.1.1 凸二次规划

这一小节回答前两件事：目标在可行集上什么时候是一只碗，这只碗什么时候只有一个最低点。答案全部来自二次函数的一个恒等式。

一个恒等式　二次函数的特别之处在于，它的高阶余项是零，局部信息就是全局信息。下面的引理把这句话写成精确的等式。

引理 20.2　二次函数的两个恒等式　设 f 是式 (20.2)中的二次函数，$\boldsymbol{Q}$ 对称。则 $\nabla f(\boldsymbol{x})=\boldsymbol{Q}\boldsymbol{x}+\boldsymbol{q}$，且对任意 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^n$ 和 $\theta\in[0,1]$，

$$f(\boldsymbol{y})=f(\boldsymbol{x})+\nabla f(\boldsymbol{x})^{\top}(\boldsymbol{y}-\boldsymbol{x})+\frac{1}{2}(\boldsymbol{y}-\boldsymbol{x})^{\top}\boldsymbol{Q}(\boldsymbol{y}-\boldsymbol{x}), \tag{20.3}$$

$$\begin{aligned} f(\theta\boldsymbol{x}+(1-\theta)\boldsymbol{y}) &= \theta f(\boldsymbol{x})+(1-\theta)f(\boldsymbol{y}) \\ &\quad -\frac{1}{2}\theta(1-\theta)(\boldsymbol{x}-\boldsymbol{y})^{\top}\boldsymbol{Q}(\boldsymbol{x}-\boldsymbol{y}). \end{aligned} \tag{20.4}$$

证明　记 $\boldsymbol{d} = \boldsymbol{y} - \boldsymbol{x}$。直接展开，

$$f(\boldsymbol{x}+\boldsymbol{d}) = \frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{Q}\boldsymbol{x} + \boldsymbol{x}^{\top}\boldsymbol{Q}\boldsymbol{d} + \frac{1}{2}\boldsymbol{d}^{\top}\boldsymbol{Q}\boldsymbol{d} + \boldsymbol{q}^{\top}\boldsymbol{x} + \boldsymbol{q}^{\top}\boldsymbol{d}.$$

把含 $\boldsymbol{d}$ 一次的两项合并成 $(\boldsymbol{Q}\boldsymbol{x}+\boldsymbol{q})^{\top}\boldsymbol{d}$，就是式 (20.3)。对 $\boldsymbol{d}$ 的一次项系数就是梯度。

再证式 (20.4)。令 $\boldsymbol{d} = \boldsymbol{x}-\boldsymbol{y}$，则 $\theta\boldsymbol{x}+(1-\theta)\boldsymbol{y} = \boldsymbol{y}+\theta\boldsymbol{d}$。由式 (20.3)，

$$f(\boldsymbol{y}+\theta\boldsymbol{d}) = f(\boldsymbol{y}) + \theta\nabla f(\boldsymbol{y})^{\top}\boldsymbol{d} + \frac{1}{2}\theta^{2}\boldsymbol{d}^{\top}\boldsymbol{Q}\boldsymbol{d}.$$

同一公式取步长 1，得到

$$f(\boldsymbol{x}) = f(\boldsymbol{y}) + \nabla f(\boldsymbol{y})^{\top}\boldsymbol{d} + \frac{1}{2}\boldsymbol{d}^{\top}\boldsymbol{Q}\boldsymbol{d}.$$

于是

$$\theta f(\boldsymbol{x}) + (1-\theta) f(\boldsymbol{y}) = f(\boldsymbol{y}) + \theta\nabla f(\boldsymbol{y})^{\top}\boldsymbol{d} + \frac{1}{2}\theta\boldsymbol{d}^{\top}\boldsymbol{Q}\boldsymbol{d}.$$

两式相减，差等于 $\frac{1}{2}(\theta^{2}-\theta)\boldsymbol{d}^{\top}\boldsymbol{Q}\boldsymbol{d}$，即式 (20.4)最后一项。 ■

式 (20.4)说，弦上的点比弦下面的函数值高出多少，完全由 $(\boldsymbol{x}-\boldsymbol{y})^{\top}\boldsymbol{Q}(\boldsymbol{x}-\boldsymbol{y})$ 决定。线性项在其中不起作用。这一项为正，函数在这条线段上向下弯成碗；为负，则向上拱起。

因此要判断凸性，只需要看 $\boldsymbol{Q}$ 在所有“两个可行点之差”上的符号。方向若永远走不到，它的曲率再负也无妨。

只看可行差方向　把可行差张成的子空间记为

$$\boldsymbol{V} = \operatorname{span}\{\boldsymbol{x}-\boldsymbol{y} : \boldsymbol{x}, \boldsymbol{y} \in \boldsymbol{C}\}, \tag{20.5}$$

并取 $\boldsymbol{Z}$ 为一个矩阵，其各列构成 $\boldsymbol{V}$ 的基。若 $\boldsymbol{C}$ 中存在严格满足全部不等式的点，且 $\boldsymbol{A}$ 的约束相容，则 $\boldsymbol{V} = \ker \boldsymbol{A}$；此时 $\boldsymbol{Z}$ 就是 $\boldsymbol{A}$ 的零空间基。矩阵 $\boldsymbol{Z}^{\top}\boldsymbol{Q}\boldsymbol{Z}$ 记录了 $\boldsymbol{Q}$ 在可行方向上的全部曲率。

定理 20.3　可行集上的凸性　设 $\boldsymbol{C}$ 是式 (20.2)的非空可行集，$\boldsymbol{Z}$ 的各列是 $\boldsymbol{V}$ 的基。则

1. f 在 $\boldsymbol{C}$ 上凸，当且仅当 $\boldsymbol{Z}^{\top}\boldsymbol{Q}\boldsymbol{Z} \succeq \boldsymbol{0}$；
2. f 在 $\boldsymbol{C}$ 上严格凸，当且仅当 $\boldsymbol{Z}^{\top}\boldsymbol{Q}\boldsymbol{Z} \succ \boldsymbol{0}$。

特别地，$\boldsymbol{Q} \succeq \boldsymbol{0}$ 时 f 在任何凸集上都凸。

证明 先说明可行差足以探测 $\boldsymbol{V}$ 中的每个方向。非空凸集在它的仿射包内有内点，取这样一个点 $\bar{\boldsymbol{x}}$。存在 $\varepsilon > 0$，使得对 $\boldsymbol{V}$ 中满足 $\|\boldsymbol{d}\|_2 \le \varepsilon$ 的 $\boldsymbol{d}$，都有 $\bar{\boldsymbol{x}} + \boldsymbol{d} \in \boldsymbol{C}$。所以这样的 $\boldsymbol{d}$ 是可行差，$\boldsymbol{V}$ 中任一非零方向乘上适当的正数后都是可行差。

设 f 在 $\boldsymbol{C}$ 上凸。对 $\boldsymbol{x} = \bar{\boldsymbol{x}} + \boldsymbol{d}$ 和 $\boldsymbol{y} = \bar{\boldsymbol{x}}$，式 (20.4)中的最后一项必须不为正，故 $\boldsymbol{d}^{\top}\boldsymbol{Q}\boldsymbol{d} \ge 0$。缩放后对 $\boldsymbol{V}$ 中全部方向成立，这就是 $\boldsymbol{Z}^{\top}\boldsymbol{Q}\boldsymbol{Z} \succeq \boldsymbol{0}$。

反过来，若 $\boldsymbol{Z}^{\top}\boldsymbol{Q}\boldsymbol{Z} \succeq \boldsymbol{0}$，则对任意 $\boldsymbol{x}, \boldsymbol{y} \in \boldsymbol{C}$，$\boldsymbol{x} - \boldsymbol{y} \in \boldsymbol{V}$，式 (20.4)中的最后一项不为正，$f$ 在 $\boldsymbol{C}$ 上凸。

严格凸的情形相同。取 $\boldsymbol{x} \neq \boldsymbol{y}$ 和 $\theta \in (0,1)$，式 (20.4)说明弦严格高于函数，当且仅当 $(\boldsymbol{x}-\boldsymbol{y})^{\top}\boldsymbol{Q}(\boldsymbol{x}-\boldsymbol{y}) > 0$。把上面两段的非负换成严格为正，论证逐句成立。 ■

最小二乘天然满足定理的条件。对 $\boldsymbol{Q} = \boldsymbol{D}^{\top}\boldsymbol{D}$，有

$$\boldsymbol{d}^{\top}\boldsymbol{Q}\boldsymbol{d} = \|\boldsymbol{D}\boldsymbol{d}\|_2^2 \ge 0.$$

所以带线性约束的最小二乘总是凸二次规划。严格凸与否取决于 $\ker \boldsymbol{D}$ 与 $\boldsymbol{V}$ 是否只交于零向量。例中 $\boldsymbol{D}$ 列满秩，$\boldsymbol{Q}$ 的特征值是 1 和 3，全空间正定。

连接线性方程与最优性条件 没有约束时，最优条件是 $\boldsymbol{Q}\boldsymbol{x} + \boldsymbol{q} = \boldsymbol{0}$，也就是最小二乘的正规方程 $\boldsymbol{D}^{\top}\boldsymbol{D}\boldsymbol{x} = \boldsymbol{D}^{\top}\boldsymbol{r}$，其解法和选解可参考卷二第 11 章“线性方程与最小二乘的选解”。例中由式 (20.1)解得无约束解 $(2,1)$。

加上约束后，方程要换成第 17章的 KKT 条件。那一章证明了：约束全是仿射函数时，局部极小点满足 KKT 条件，不需要额外的约束规格。对问题 (20.2)，KKT 条件写成存在 $\boldsymbol{\lambda} \in \mathbb{R}^m$ 和 $\boldsymbol{\nu} \in \mathbb{R}^p$，使得

$$\begin{aligned} &\boldsymbol{Q}\boldsymbol{x} + \boldsymbol{q} + \boldsymbol{A}^{\top}\boldsymbol{\nu} + \boldsymbol{G}^{\top}\boldsymbol{\lambda} = \boldsymbol{0}, \\ &\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}, \qquad \boldsymbol{G}\boldsymbol{x} \le \boldsymbol{h}, \\ &\boldsymbol{\lambda} \ge \boldsymbol{0}, \qquad \boldsymbol{\lambda}^{\top}(\boldsymbol{G}\boldsymbol{x} - \boldsymbol{h}) = 0. \end{aligned} \tag{20.6}$$

凸性让这组条件从必要变成充分，也就成了全局最优的证书。

定理 20.4 凸二次规划的 KKT 证书 设 f 在 $\boldsymbol{C}$ 上凸。可行点 $\boldsymbol{x}$ 是问题 (20.2)的全局最优解，当且仅当存在 $\boldsymbol{\lambda}, \boldsymbol{\nu}$ 使式 (20.6)成立。

证明　必要性是上面复述的结论，全局最优解当然是局部极小点。下面证充分性。任取可行点 $\boldsymbol{y}$，记 $\boldsymbol{d}=\boldsymbol{y}-\boldsymbol{x}$。由式 (20.3)，

$$f(\boldsymbol{y})-f(\boldsymbol{x})=\nabla f(\boldsymbol{x})^{\top}\boldsymbol{d}+\frac{1}{2}\boldsymbol{d}^{\top}\boldsymbol{Q}\boldsymbol{d}.$$

$\boldsymbol{d}$ 是可行差，定理 20.3给出 $\boldsymbol{d}^{\top}\boldsymbol{Q}\boldsymbol{d}\geq 0$。只需证第一项非负。

把驻定条件代入，并用 $\boldsymbol{A}\boldsymbol{d}=\boldsymbol{0}$，得到

$$\nabla f(\boldsymbol{x})^{\top}\boldsymbol{d}=-\boldsymbol{\nu}^{\top}\boldsymbol{A}\boldsymbol{d}-\boldsymbol{\lambda}^{\top}\boldsymbol{G}\boldsymbol{d}=-\boldsymbol{\lambda}^{\top}\boldsymbol{G}\boldsymbol{d}.$$

由互补条件 $\boldsymbol{\lambda}^{\top}(\boldsymbol{G}\boldsymbol{x}-\boldsymbol{h})=0$，上式可以写成

$$-\boldsymbol{\lambda}^{\top}\boldsymbol{G}\boldsymbol{d}=-\boldsymbol{\lambda}^{\top}(\boldsymbol{G}\boldsymbol{y}-\boldsymbol{h})+\boldsymbol{\lambda}^{\top}(\boldsymbol{G}\boldsymbol{x}-\boldsymbol{h})=-\boldsymbol{\lambda}^{\top}(\boldsymbol{G}\boldsymbol{y}-\boldsymbol{h}).$$

$\boldsymbol{\lambda}\geq\boldsymbol{0}$ 且 $\boldsymbol{G}\boldsymbol{y}\leq\boldsymbol{h}$，所以右端非负。于是 $f(\boldsymbol{y})\geq f(\boldsymbol{x})$。 ■

这个证书的好处是核对便宜。给出 $\boldsymbol{x}$ 和 $\boldsymbol{\lambda}$，只需做几次矩阵乘法，不必重新求解。

示例 20.5　核对预算问题的解　猜测预算活动、非负约束不活动。可行点 $(3/2,1/2)$ 如何得来，下一小节再算，这里先核对。由式 (20.1)，

$$\nabla f(\boldsymbol{x})=\boldsymbol{Q}\boldsymbol{x}+\boldsymbol{q}=\begin{bmatrix}7/2\\5/2\end{bmatrix}+\begin{bmatrix}-5\\-4\end{bmatrix}=\begin{bmatrix}-3/2\\-3/2\end{bmatrix}.$$

取 $\boldsymbol{\lambda}=(3/2,0,0)$，则

$$\nabla f(\boldsymbol{x})+\boldsymbol{G}^{\top}\boldsymbol{\lambda}=\begin{bmatrix}-3/2\\-3/2\end{bmatrix}+\frac{3}{2}\begin{bmatrix}1\\1\end{bmatrix}=\boldsymbol{0}.$$

互补条件成立，因为预算的松弛量是 0，另外两条约束的乘子是 0。$\boldsymbol{\lambda}\geq\boldsymbol{0}$ 也成立。由定理 20.4，$(3/2,1/2)$ 是全局最优解。

最优值按 $\frac{1}{2}\|\boldsymbol{D}\boldsymbol{x}-\boldsymbol{r}\|_2^2$ 计算。残差是 $\boldsymbol{D}\boldsymbol{x}-\boldsymbol{r}=(-2,1/2,1/2)$，于是

$$f^{\star}=\frac{1}{2}\Big(4+\frac{1}{4}+\frac{1}{4}\Big)=\frac{9}{4}.$$

解的存在与唯一　凸性不保证最优解存在。$\frac{1}{2}x_1^2+x_2$ 的 $\boldsymbol{Q}$ 半正定，在全平面上却无下界，沿 $x_2\to-\infty$ 一路下降。有下界时情况好得多：二次函数只要在非空多面体上有下界，就一定取得最小值。这一结论称为 Frank–Wolfe 定理，它不要求凸性；证明要对约束个数作归纳，处理最小化序列沿回收方向发散的情形，篇幅较长，读者可查阅二次规划方面的专著。

这里有一点值得和一般光滑函数对比。第 1章的 e^x 在全直线上有下界 0，却取不到。二次函数不会有这样的渐近行为。

唯一性由曲率直接给出，而且只需要看可行差方向。

定理 20.6　存在唯一性的充分条件　设 $\boldsymbol{C}$ 非空，且对 $\boldsymbol{V}$ 中每个非零 $\boldsymbol{d}$ 都有 $\boldsymbol{d}^{\top}\boldsymbol{Q}\boldsymbol{d} > 0$。则问题 (20.2)恰有一个最优解。

证明　先证存在。取 $\bar{\boldsymbol{x}} \in \boldsymbol{C}$，$\boldsymbol{C}$ 中的点都可写成 $\bar{\boldsymbol{x}} + \boldsymbol{Z}\boldsymbol{u}$。此时 f 成为 $\boldsymbol{u}$ 的二次函数，其二次项矩阵 $\boldsymbol{Z}^{\top}\boldsymbol{Q}\boldsymbol{Z}$ 正定，故 $\|\boldsymbol{u}\|_2 \to \infty$ 时函数值趋于 $+\infty$，下水平集有界。可行集是闭集，所以下水平集紧，第 1章的存在定理给出最优解。

再证唯一。设 $\boldsymbol{x} \neq \boldsymbol{y}$ 都是最优解，中点 $\boldsymbol{z} = (\boldsymbol{x}+\boldsymbol{y})/2$ 可行。对式 (20.4)取 $\theta = 1/2$，并记 $\boldsymbol{d} = \boldsymbol{x} - \boldsymbol{y} \in \boldsymbol{V}$，得到

$$f(\boldsymbol{z}) = f^{\star} - \frac{1}{8}\boldsymbol{d}^{\top}\boldsymbol{Q}\boldsymbol{d} < f^{\star}.$$

这与 $f^{\star}$ 是最优值矛盾。 ■

定理要求的是 $\boldsymbol{V}$ 上正定，不是全空间正定。图 20.2比较了三种情形。

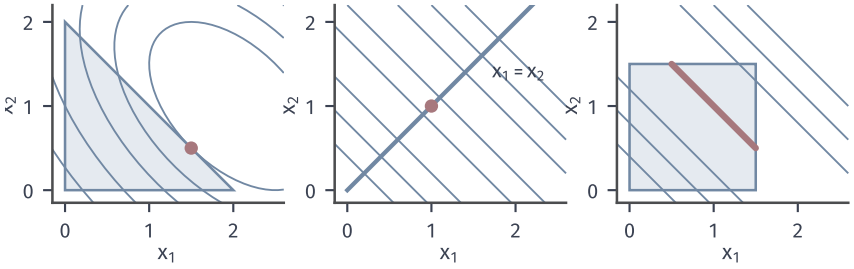


图 20.2　曲率与解的唯一性，蓝线是目标等高线，红色是解集。(a) 预算问题，$\boldsymbol{Q}$ 全空间正定，解唯一。(b) 目标 $\frac{1}{2}(x_1 + x_2 - 2)^2$ 的 $\boldsymbol{Q}$ 奇异，等高线是平行直线；约束直线 $x_1 = x_2$ 与谷底方向横截，解唯一。(c) 同一目标，可行集是正方形 $[0, 3/2]^2$，平坦方向 $(1, -1)$ 落在可行差内，解集是一条线段。

(b) 中的目标来自只有一次观测的最小二乘，$\boldsymbol{D} = \begin{bmatrix} 1 & 1 \end{bmatrix}$，$\boldsymbol{r} = (2)$，于是 $\boldsymbol{Q} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$ 奇异，其零空间由 $(1, -1)$ 张成。约束 $x_1 = x_2$ 使 $\boldsymbol{V}$ 由 $(1, 1)$ 张成，而

$$(1,1)\,\boldsymbol{Q}\,(1,1)^{\top} = 4 > 0.$$

20.1 二次规划
20.1.1 凸二次规划
20.1.2 等式约束二次问题
20.1.3 非凸二次问题
20.2 锥规划
20.3 等价改写
20.4 半正定松弛
20.5 模型与求解方法
20.6 本章小结

所以在可行直线上目标严格凸，解 $(1,1)$ 唯一。全空间正定不是必要条件。

(c) 中可行集仍是平面区域，平坦方向 $(1,-1)$ 属于 $\boldsymbol{V}$，定理的条件不成立，结论也确实不成立：线段 $x_1+x_2=2$ 上的点全部最优，目标值都是 0。

$\boldsymbol{V}$ 上正定同样不是唯一性的必要条件。考虑 $\frac{1}{2}x_1^2+x_2$，约束 $x_2\ge 0$。这里 $\boldsymbol{V}=\mathbb{R}^2$，方向 $(0,1)$ 的曲率为零，但线性项把解推到边界上：目标在可行集上非负，且只在原点为零，解唯一。线性规划是更极端的情形，$\boldsymbol{Q}=\boldsymbol{0}$，解却常常是唯一的顶点。

解集与可复用的运算　凸二次规划的解不唯一时，解集也有规律。设 $\boldsymbol{x},\boldsymbol{y}$ 都最优，式 (20.4)迫使 $\boldsymbol{d}^{\top}\boldsymbol{Q}\boldsymbol{d}=0$，其中 $\boldsymbol{d}=\boldsymbol{x}-\boldsymbol{y}$。$\boldsymbol{Q}\succeq\boldsymbol{0}$ 时这又推出 $\boldsymbol{Q}\boldsymbol{d}=\boldsymbol{0}$，所以各最优解的梯度相同。解集上变的只有沿平坦方向的位置，不变的是梯度和最优值。

至于第三件事，二次规划的计算几乎都落到线性方程上。$\boldsymbol{Q}=\boldsymbol{D}^{\top}\boldsymbol{D}$ 时，$\boldsymbol{D}$ 的 QR 分解可以反复使用；求解过程换一组活动约束时，只需更新分解，不必重做。求解的形式与代价要到不等式的处理方法确定后才能比较，下一小节先看只有等式的情形。

20.1.2 等式约束二次问题

假如已经知道哪些不等式在解处活动，把它们当作等式，问题就只剩等式约束。这一小节研究

$$\min_{\boldsymbol{x}}\ \frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{Q}\boldsymbol{x}+\boldsymbol{q}^{\top}\boldsymbol{x}\quad\text{s.t.}\quad\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b},\tag{20.7}$$

其中 $\boldsymbol{A}\in\mathbb{R}^{p\times n}$ 行满秩，$p<n$。要回答的问题是：它能否化成一次线性方程，什么时候这个方程给出的确实是极小点？

例子取预算恰好用完的情形：$\boldsymbol{A}=\begin{bmatrix}1 & 1\end{bmatrix}$，$b=2$，$\boldsymbol{Q},\boldsymbol{q}$ 如式 (20.1)。可行集是平面上的一条直线。

可行集是一张平的“纸”，有两种自然的处理方式。一种是在纸上另取坐标，把问题变成无约束问题，只看纸面上的碗。另一种是留在原坐标里，引入乘子，把“不许离开纸面”变成方程。

零空间参数化　取一个特解 $\boldsymbol{x}_{\mathrm{p}}$ 满足 $\boldsymbol{A}\boldsymbol{x}_{\mathrm{p}}=\boldsymbol{b}$，取 $\boldsymbol{Z}\in\mathbb{R}^{n\times(n-p)}$，其各列是 $\ker\boldsymbol{A}$ 的基。每个可行点都唯一地写成

$$\boldsymbol{x}=\boldsymbol{x}_{\mathrm{p}}+\boldsymbol{Z}\boldsymbol{u},\qquad\boldsymbol{u}\in\mathbb{R}^{n-p}.\tag{20.8}$$

约束被消去，$\boldsymbol{u}$ 可以取任意值。

把式 (20.8)代入目标，并用式 (20.3)以 $\boldsymbol{x}_{\mathrm{p}}$ 为中心展开，得到 $\boldsymbol{u}$ 的二次函数

$$\varphi(\boldsymbol{u}) = f(\boldsymbol{x}_{\mathrm{p}}) + \big(\boldsymbol{Z}^{\top}(\boldsymbol{Q}\boldsymbol{x}_{\mathrm{p}} + \boldsymbol{q})\big)^{\top}\boldsymbol{u} + \frac{1}{2}\boldsymbol{u}^{\top}\boldsymbol{Z}^{\top}\boldsymbol{Q}\boldsymbol{Z}\boldsymbol{u}. \tag{20.9}$$

矩阵 $\boldsymbol{Z}^{\top}\boldsymbol{Q}\boldsymbol{Z}$ 称为**约化 Hessian**（reduced Hessian），它是目标在纸面上的曲率。令梯度为零，得到约化方程

$$\boldsymbol{Z}^{\top}\boldsymbol{Q}\boldsymbol{Z}\,\boldsymbol{u} = -\boldsymbol{Z}^{\top}(\boldsymbol{Q}\boldsymbol{x}_{\mathrm{p}} + \boldsymbol{q}). \tag{20.10}$$

在例子中取特解 $\boldsymbol{x}_{\mathrm{p}} = (2,0)$ 和方向 $\boldsymbol{z} = (1,-1)$。约化 Hessian 是一个数：

$$\boldsymbol{z}^{\top}\boldsymbol{Q}\boldsymbol{z} = 2 - 1 - 1 + 2 = 2.$$

$\boldsymbol{x}_{\mathrm{p}}$ 处的梯度是

$$\boldsymbol{Q}\boldsymbol{x}_{\mathrm{p}} + \boldsymbol{q} = \begin{bmatrix} 4 \\ 2 \end{bmatrix} + \begin{bmatrix} -5 \\ -4 \end{bmatrix} = \begin{bmatrix} -1 \\ -2 \end{bmatrix}.$$

它在 $\boldsymbol{z}$ 上的投影是 $\boldsymbol{z}^{\top}(\boldsymbol{Q}\boldsymbol{x}_{\mathrm{p}} + \boldsymbol{q}) = 1$。把两个数代入式 (20.10)，得到

$$2u = -1, \qquad u^{\star} = -\frac{1}{2}.$$

于是

$$\boldsymbol{x}^{\star} = \begin{bmatrix} 2 \\ 0 \end{bmatrix} - \frac{1}{2}\begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 3/2 \\ 1/2 \end{bmatrix}.$$

这个点的两个分量都是正的，所以它也满足原来的非负约束，这正是例 20.5核对过的解。

图 20.3(b) 画出约化后的一元函数 $\varphi(u) = u^{2} + u + 5/2$。原问题的约束已经不见了，剩下的是一个普通的抛物线。

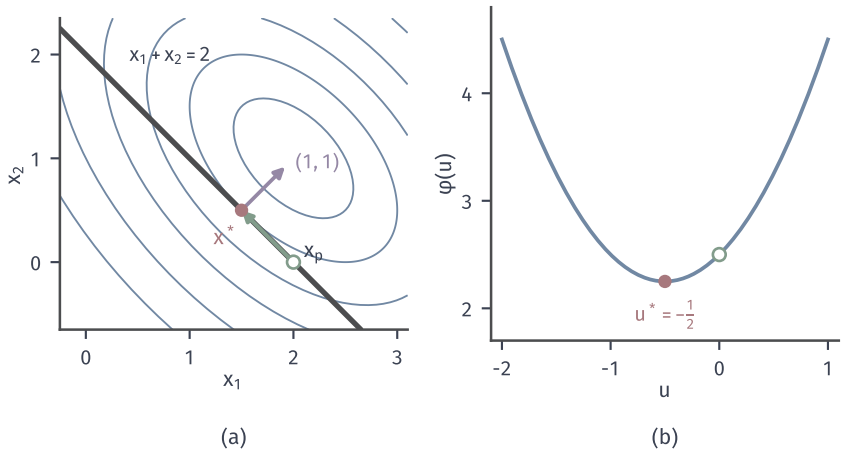


图 20.3 预算恰好用完时的二次问题。(a) 深灰粗线是可行直线，蓝线是目标等高线。从特解 $\boldsymbol{x}_{\mathrm{p}}=(2,0)$（绿色空心点）沿零空间方向走到解（红点），绿色箭头是位移 $u^{\star}\boldsymbol{z}$。紫色箭头是约束的法向 $(1,1)$，解处的等高线与直线相切，梯度沿这个方向。(b) 沿直线的一元函数 $\varphi(u)=u^2+u+5/2$，空心点和红点对应 (a) 中的 $\boldsymbol{x}_{\mathrm{p}}$ 与解。

带乘子的块线性方程 第二种做法不换坐标。对式 (20.7)写 KKT 条件，没有不等式，式 (20.6)只剩两行，它们都是线性的。写成块形式：

$$\begin{bmatrix} \boldsymbol{Q} & \boldsymbol{A}^{\mathsf{T}} \\ \boldsymbol{A} & \boldsymbol{0} \end{bmatrix} \begin{bmatrix} \boldsymbol{x} \\ \boldsymbol{\nu} \end{bmatrix} = \begin{bmatrix} -\boldsymbol{q} \\ \boldsymbol{b} \end{bmatrix}. \tag{20.11}$$

左端的矩阵称为KKT 矩阵（KKT matrix）。它对称，但不定，下方块是零。

例中方程组是

$$\begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \nu \end{bmatrix} = \begin{bmatrix} 5 \\ 4 \\ 2 \end{bmatrix}.$$

前两行相减消去 ν，得到 $x_1-x_2=1$。第三行给出 $x_1+x_2=2$。两式联立，

$$x_1=\frac{3}{2}, \qquad x_2=\frac{1}{2}.$$

再代回第一行，

$$\nu = 5-2x_1-x_2 = \frac{3}{2}.$$

得到的 $\boldsymbol{x}$ 与零空间参数化相同，还多了一个乘子。乘子的含义是预算的影子价格：预算增加一点点，最优值约按 ν 的速率下降，这种变化率的一般讨论在第 19章。

两种做法解的是同一组条件。约束 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 由参数化自动满足，而 $\ker \boldsymbol{A}$ 的正交补是 $\boldsymbol{A}^{\top}$ 的列空间，所以下面两件事等价：

$$\boldsymbol{Q}\boldsymbol{x}+\boldsymbol{q}\in \operatorname{range}(\boldsymbol{A}^{\top}) \quad\Longleftrightarrow\quad \boldsymbol{Z}^{\top}(\boldsymbol{Q}\boldsymbol{x}+\boldsymbol{q})=\boldsymbol{0}. \tag{20.12}$$

左边是块方程第一行“存在 $\boldsymbol{\nu}$”的说法，右边代入式 (20.8)就是约化方程。

表 20.1比较两种做法的计算任务。

	零空间参数化	块线性方程
需要准备	特解与零空间基 $\boldsymbol{Z}$	无
解的方程	$(n-p)$ 阶，常可用 Cholesky	$(n+p)$ 阶，对称不定
适合的情形	$n-p$ 小，$\boldsymbol{Z}$ 易得	$\boldsymbol{Q}$、$\boldsymbol{A}$ 稀疏
副产品	乘子需另算	直接得到乘子

表 20.1　等式约束二次问题的两种解法。$\boldsymbol{Z}$ 通常来自 $\boldsymbol{A}^{\top}$ 的 QR 分解，$\boldsymbol{Q}$、$\boldsymbol{A}$ 稀疏时 $\boldsymbol{Z}$ 和 $\boldsymbol{Z}^{\top}\boldsymbol{Q}\boldsymbol{Z}$ 可能变稠密。

唯一可解的条件　块方程什么时候有唯一解？式 (20.12)提示答案取决于约化 Hessian，而不是 $\boldsymbol{Q}$ 本身。

定理 20.7　KKT 矩阵的可逆性　设 $\boldsymbol{A}\in\mathbb{R}^{p\times n}$ 行满秩，$\boldsymbol{Z}$ 的各列是 $\ker \boldsymbol{A}$ 的基。则

1. KKT 矩阵可逆，当且仅当 $\boldsymbol{Z}^{\top}\boldsymbol{Q}\boldsymbol{Z}$ 可逆；
2. 若 $\boldsymbol{Z}^{\top}\boldsymbol{Q}\boldsymbol{Z}\succ\boldsymbol{0}$，则式 (20.11)有唯一解，其中的 $\boldsymbol{x}$ 是问题 (20.7)唯一的全局最优解。

证明　设 $(\boldsymbol{d},\boldsymbol{w})$ 在 KKT 矩阵的零空间中，即

$$\boldsymbol{Q}\boldsymbol{d}+\boldsymbol{A}^{\top}\boldsymbol{w}=\boldsymbol{0},\qquad \boldsymbol{A}\boldsymbol{d}=\boldsymbol{0}.$$

由第二式可写 $\boldsymbol{d}=\boldsymbol{Z}\boldsymbol{u}$。第一式左乘 $\boldsymbol{Z}^{\top}$，因为 $\boldsymbol{A}\boldsymbol{Z}=\boldsymbol{0}$，得到 $\boldsymbol{Z}^{\top}\boldsymbol{Q}\boldsymbol{Z}\boldsymbol{u}=\boldsymbol{0}$。

若 $\boldsymbol{Z}^{\top}\boldsymbol{Q}\boldsymbol{Z}$ 可逆，则 $\boldsymbol{u}=\boldsymbol{0}$，$\boldsymbol{d}=\boldsymbol{0}$。此时第一式成为 $\boldsymbol{A}^{\top}\boldsymbol{w}=\boldsymbol{0}$，$\boldsymbol{A}$ 行满秩推出 $\boldsymbol{w}=\boldsymbol{0}$。所以 KKT 矩阵可逆。

反过来，若存在 $\boldsymbol{u}\neq\boldsymbol{0}$ 使 $\boldsymbol{Z}^{\top}\boldsymbol{Q}\boldsymbol{Z}\boldsymbol{u}=\boldsymbol{0}$，令 $\boldsymbol{d}=\boldsymbol{Z}\boldsymbol{u}\neq\boldsymbol{0}$。则 $\boldsymbol{Q}\boldsymbol{d}$ 与 $\ker \boldsymbol{A}$ 正交，属于 $\operatorname{range}(\boldsymbol{A}^{\top})$，存在 $\boldsymbol{w}$ 使 $\boldsymbol{Q}\boldsymbol{d}+\boldsymbol{A}^{\top}\boldsymbol{w}=\boldsymbol{0}$。$(\boldsymbol{d},\boldsymbol{w})$ 是非零的零空间向量，KKT 矩阵奇异。第一条得证。

> 第二条的可逆性由第一条给出。此时 φ 严格凸，其唯一驻点是唯一的全局极小点；由式 (20.12)，这个驻点正是块方程解中的 $\boldsymbol{x}$。 ■

定理中的“行满秩”也是必需的。若 $\boldsymbol{A}$ 行亏秩，存在 $\boldsymbol{w} \neq \boldsymbol{0}$ 使 $\boldsymbol{A}^{\mathsf{T}}\boldsymbol{w} = \boldsymbol{0}$，$(\boldsymbol{0}, \boldsymbol{w})$ 就在零空间里，块方程要么无解，要么乘子不唯一。

可逆不等于极小 线性方程组非奇异，只说明驻点存在且唯一，并不说明驻点是极小点。第一条与第二条之间差的正是约化曲率的符号。

取 $\boldsymbol{Q} = \operatorname{diag}(1, -1)$，$\boldsymbol{q} = \boldsymbol{0}$，约束是过原点的直线，方向为 $\boldsymbol{z}$。图 20.4比较了三个方向。目标沿直线 $\boldsymbol{x} = s\boldsymbol{z}$ 的值是 $\frac{1}{2}s^2\boldsymbol{z}^{\mathsf{T}}\boldsymbol{Q}\boldsymbol{z}$，约化 Hessian 就是数 $\boldsymbol{z}^{\mathsf{T}}\boldsymbol{Q}\boldsymbol{z}$。

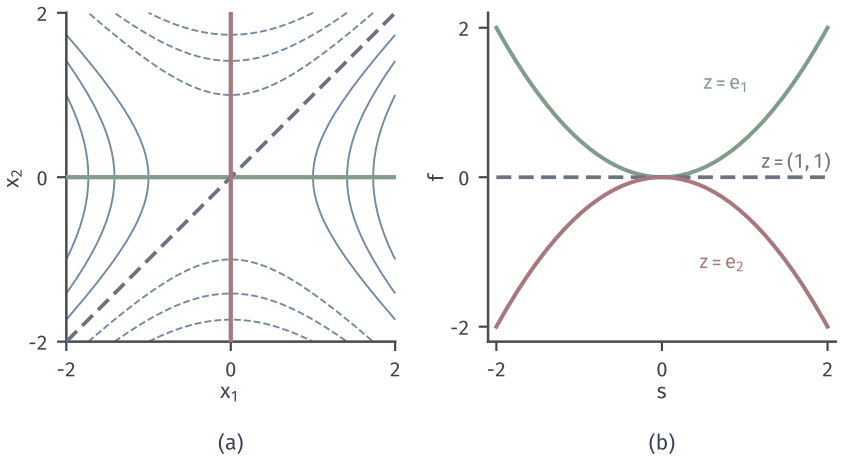


图 20.4 约化曲率决定驻点的性质。目标 $\frac{1}{2}(x_1^2 - x_2^2)$，$\boldsymbol{q} = \boldsymbol{0}$。(a) 蓝线是等高线（实线为正值，虚线为负值），三条直线是过原点的可行集。(b) 目标沿每条直线的取值，横轴是直线上的坐标。绿线的约化曲率为 1，灰色虚线为 0，红线为 −1。

表 20.2列出三种结果。

方向 $\boldsymbol{z}$	$\boldsymbol{z}^{\mathsf{T}}\boldsymbol{Q}\boldsymbol{z}$	KKT 矩阵	原点的性质
$(1, 0)$	1	可逆	唯一全局极小点
$(1, 1)$	0	奇异	整条直线都是驻点
$(0, 1)$	-1	可逆	沿直线的极大点，问题无下界

表 20.2 $\boldsymbol{Q} = \operatorname{diag}(1, -1)$、$\boldsymbol{q} = \boldsymbol{0}$ 时，约束直线的方向决定 KKT 矩阵和驻点的性质。

20.1 二次规划
20.1.1 凸二次规划
20.1.2 等式约束二次问题
20.1.3 非凸二次问题
20.2 锥规划
20.3 等价改写
20.4 半正定松弛
20.5 模型与求解方法
20.6 本章小结

第三行是要警惕的情形。此时约束是 $x_1 = 0$，$\boldsymbol{A} = \begin{bmatrix} 1 & 0 \end{bmatrix}$，块方程的矩阵

$$\begin{bmatrix} 1 & 0 & 1 \\ 0 & -1 & 0 \\ 1 & 0 & 0 \end{bmatrix}$$

行列式为 1，可逆，解是 $\boldsymbol{x} = \boldsymbol{0}$、$\nu = 0$。求解器不会报告任何异常，但 $(0, s)$ 处的目标是 $-\frac{1}{2}s^2$，$\boldsymbol{x} = \boldsymbol{0}$ 是沿可行直线的最高点。

所以解完块方程还要核对约化曲率。不想构造 $\boldsymbol{Z}$ 时可以看 KKT 矩阵的惯性：$\boldsymbol{A}$ 行满秩时，KKT 矩阵恰有 n 个正特征值、p 个负特征值，当且仅当 $\boldsymbol{Z}^{\top}\boldsymbol{Q}\boldsymbol{Z} \succ \boldsymbol{0}$，而对称不定分解能直接读出惯性[1]。

含不等式时，还要决定哪些不等式按等式处理，这个选择问题以及逐步调整的求解方法在第 23章展开。

[1] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

20.1.3 非凸二次问题

$\boldsymbol{Q}$ 在可行差方向上有负曲率时，前面的两个定理都不能用。这一小节要弄清：负曲率到底造成什么后果，约束又能挽回多少？

一个负曲率的例子 考虑 $\boldsymbol{Q} = \mathrm{diag}(1, -1)$ 的目标

$$f(\boldsymbol{x}) = \frac{1}{2}x_1^2 - \frac{1}{2}x_2^2 + \frac{1}{4}x_2. \tag{20.13}$$

沿 x_1 方向是碗，沿 x_2 方向是倒扣的碗。

先不加约束。唯一的驻点由 $x_1 = 0$ 和 $-x_2 + \frac{1}{4} = 0$ 给出，是 $\mathrm{S} = (0, 1/4)$。沿 x_2 方向走，目标趋于 $-\infty$，所以这个问题无下界，驻点是鞍点。

现在加上 $-1 \le x_2 \le 1$。约束切断了 x_2 方向的无限下降，x_1 方向的目标又非负，所以目标在可行集上有下界。这就是图 20.5(a) 中的带形区域。

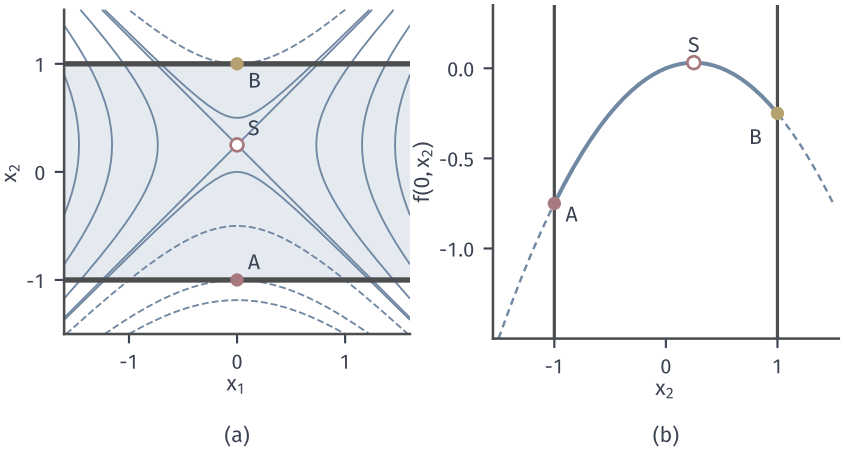


图 20.5 非凸二次问题的三个 KKT 点。目标 $\frac{1}{2}x_1^2 - \frac{1}{2}x_2^2 + \frac{1}{4}x_2$，可行集 $-1 \le x_2 \le 1$。(a) 浅蓝带形是可行集，深灰粗线是约束边界，蓝线是等高线（虚线为负的较低水平）。红色实心点 A 是全局极小点，黄点 B 是局部极小点，红色空心点 S 是鞍点。(b) 沿 $x_1 = 0$ 的目标值，两条竖线之外不可行（虚线）。

KKT 点的逐个判别 约束写成 $x_2 - 1 \le 0$ 和 $-x_2 - 1 \le 0$，乘子分别记 λ_1, λ_2。驻定条件给出 $x_1 = 0$，以及

$$-x_2 + \frac{1}{4} + \lambda_1 - \lambda_2 = 0.$$

两条约束不能同时活动，所以按活动约束只有三种情形，每一种都是一个线性方程，结果列在表 20.3中。

点	活动约束	乘子	目标值
$\mathrm{A} = (0, -1)$	$x_2 \ge -1$	$\lambda_2 = 5/4$	$-3/4$
$\mathrm{B} = (0, 1)$	$x_2 \le 1$	$\lambda_1 = 3/4$	$-1/4$
$\mathrm{S} = (0, 1/4)$	无	0	$1/32$

表 20.3 目标 (20.13)在带形可行集上的三个 KKT 点。

三个点都满足一阶条件，性质却各不相同。判别要用第 17章的二阶条件：在乘子为正的活动约束的切方向上看曲率。

在 A 和 B 处，活动约束的乘子都为正，临界方向只有 $(d_1, 0)$，曲率 $d_1^2 > 0$，所以二者都是严格局部极小点。在 S 处没有活动约束，$\boldsymbol{Q}$ 本身不定，沿 $(0, 1)$ 的曲率为负，所以 S 是鞍点。

比较目标值，A 是全局极小点，B 只是局部极小点。

20.1 二次规划
20.2 锥规划
20.2.1 二阶锥规划
20.2.2 半正定规划
20.2.3 锥对偶与证书
20.3 等价改写
20.4 半正定松弛
20.5 模型与求解方法
20.6 本章小结

不能继承的全局证书 B 满足全部 KKT 条件，却不是全局最优解。定理 20.4的证明在这里断在哪一步？取 $\boldsymbol{x} = \mathrm{B}$、$\boldsymbol{y} = \mathrm{A}$, $\boldsymbol{d} = (0, -2)$。式 (20.3)的两部分分别是

$$\nabla f(\mathrm{B})^{\top}\boldsymbol{d} = \Big(-\frac{3}{4}\Big)(-2) = \frac{3}{2}, \qquad \frac{1}{2}\boldsymbol{d}^{\top}\boldsymbol{Q}\boldsymbol{d} = -2.$$

一阶部分依然非负，这是 KKT 条件保证的。但二次部分为负，而且绝对值更大，两者之和是 $-1/2$，恰好等于 $f(\mathrm{A}) - f(\mathrm{B})$。

表 20.4把局部最优、鞍点和无下界并列起来。若只保留上界 $x_2 \le 1$、去掉下界，B 依然是严格局部极小点，问题却变成无下界。局部信息看不出全局的命运。

可行集	负曲率方向	结论
全平面	不受限制	无下界，S 是鞍点
$x_2 \le 1$	只能向下走	B 局部极小，问题无下界
$-1 \le x_2 \le 1$	被两侧截断	A 全局极小，B 局部极小，S 鞍点
$x_2 = 0$	被完全禁止	约化后严格凸，解唯一

表 20.4　同一目标 (20.13)在不同可行集上的结果。约束可以限制负曲率方向，但限制的方式决定结论。

局部解的数量 局部极小点可以非常多。在盒 $[-1, 1]^n$ 上最小化 $-\frac{1}{2}\|\boldsymbol{x}\|_2^2$，每个顶点都是严格局部极小点，共 2^n 个，且每个都满足 KKT 条件。一般非凸二次规划的全局求解是 NP 困难问题，这个结论的证明需要计算复杂性理论的归约，这里只用它说明：不能指望靠逐个检查 KKT 点解决大规模问题。

不过二次结构并没有消失。梯度仍是线性的，每猜一组活动约束仍只需解一次线性方程，局部极小点仍可以用迭代方法找到。缺的是一个能断言“再也找不到更好的点”的全局依据。第 20.4节将给出另一类下界，用来补上这个缺口。

20.2 锥规划

二次规划的约束仍是平的，可行集的边界由超平面拼成。距离上限、矩阵半正定这样的条件却给出弯曲的边界。接下来要弄清：怎样把这些弯曲的约束放进一个共同的形式，同时保留线性规划那种“任何人都能核对”的对偶下界？

从非负约束到锥约束　回看第 2章的线性规划

$$\min_{\boldsymbol{x}} \ \boldsymbol{c}^{\top}\boldsymbol{x} \quad \text{s.t.} \quad \boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}, \quad \boldsymbol{x}\geq \boldsymbol{0}.$$

目标和等式都是线性的，问题的全部“形状”集中在一条约束上：$\boldsymbol{x}$ 属于非负象限 $\mathbb{R}^n_+$。

对偶理论用到非负象限的什么性质？只有三条：它是闭集，它是凸集，它对乘以非负数封闭。保留这三条，把非负象限换成别的集合，线性规划的框架就可以搬过去。

定义 20.8　闭凸锥　设 $\boldsymbol{K}\subseteq\mathbb{R}^N$ 非空。若 $\boldsymbol{K}$ 是闭凸集，且对任意 $\boldsymbol{x}\in\boldsymbol{K}$ 和 $\theta\geq 0$ 都有 $\theta\boldsymbol{x}\in\boldsymbol{K}$，则称 $\boldsymbol{K}$ 是**闭凸锥**（closed convex cone）。

非负象限是闭凸锥。闭单位球不是，因为把球内的点放大后会跑到球外。两条相交直线的并也不是，它对放缩封闭，但不凸。

现在让仿射表达式属于这样的锥，就得到下面的共同形式。

定义 20.9　锥规划　设 $\boldsymbol{K}\subseteq\mathbb{R}^N$ 是闭凸锥，$\boldsymbol{c}\in\mathbb{R}^n$，$\boldsymbol{A}\in\mathbb{R}^{p\times n}$，$\boldsymbol{b}\in\mathbb{R}^p$，$\boldsymbol{E}\in\mathbb{R}^{N\times n}$，$\boldsymbol{g}\in\mathbb{R}^N$。问题

$$\min_{\boldsymbol{x}} \ \boldsymbol{c}^{\top}\boldsymbol{x} \quad \text{s.t.} \quad \boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}, \quad \boldsymbol{E}\boldsymbol{x}+\boldsymbol{g}\in\boldsymbol{K} \tag{20.14}$$

称为**锥规划**（conic program）。$\boldsymbol{K}$ 可以是若干个锥的直积，此时每一块分别属于对应的锥。

取 $\boldsymbol{K}=\mathbb{R}^n_+$、$\boldsymbol{E}=\boldsymbol{I}$、$\boldsymbol{g}=\boldsymbol{0}$，得到线性规划。目标依然是线性的，等式依然是线性的，全部非线性都收进了“属于 $\boldsymbol{K}$”这一句话。

可以把“$\boldsymbol{E}\boldsymbol{x}+\boldsymbol{g}\in\boldsymbol{K}$”读成广义的“大于等于零”。这个类比在一处失效：实数总能比较大小，一般的锥却给不出全序，$\boldsymbol{v}$ 和 $-\boldsymbol{v}$ 可能都不属于 $\boldsymbol{K}$。于是下面的乘子也不能再简单地说成“非负”。

对偶锥　线性规划的对偶之所以成立，是因为 $\boldsymbol{x}\geq\boldsymbol{0}$、$\boldsymbol{s}\geq\boldsymbol{0}$ 时必有 $\boldsymbol{s}^{\top}\boldsymbol{x}\geq 0$。换成一般的锥，要问：什么样的向量 $\boldsymbol{s}$ 与 $\boldsymbol{K}$ 中每个向量的内积都非负？

定义 20.10　对偶锥　闭凸锥 $\boldsymbol{K}\subseteq\mathbb{R}^N$ 的**对偶锥**（dual cone）是

$$\boldsymbol{K}^{*}=\{\boldsymbol{s}\in\mathbb{R}^N:\langle\boldsymbol{s},\boldsymbol{x}\rangle\geq 0 \text{ 对所有}\boldsymbol{x}\in\boldsymbol{K}\text{ 成立}\}. \tag{20.15}$$

把 $\boldsymbol{s}$ 看成一组价格，$\boldsymbol{x}\in\boldsymbol{K}$ 看成一份允许的持仓，$\langle\boldsymbol{s},\boldsymbol{x}\rangle$ 就是持仓的价值。对偶锥里的价格保证：无论持有 $\boldsymbol{K}$ 中哪一份，价值都不为负。这个类

比的边界在于，价格的单个分量可以是负的，只要 $\boldsymbol{K}$ 中的向量不会让总价值变负就行。

图 20.6画出平面上的三个例子，几何上 $\boldsymbol{K}^*$ 由与 $\boldsymbol{K}$ 中所有方向夹角不超过直角的方向组成。

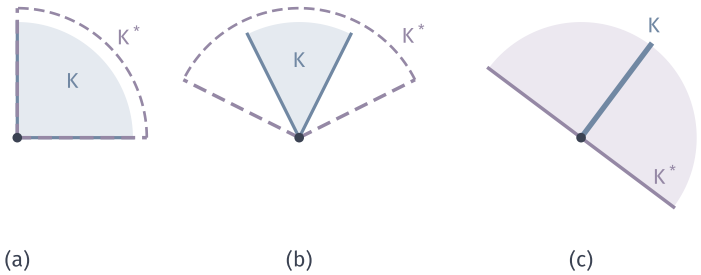


图 20.6 平面上的锥（蓝色）与对偶锥（紫色）。(a) 第一象限的对偶锥是它自身，紫色虚线与蓝色边界重合。(b) 窄锥 $\{(u,t) : |u| \le t/2\}$ 的对偶锥是宽锥 $\{(v,w) : |v| \le 2w\}$。(c) 一条射线的对偶锥是一个闭半平面。各锥只画出原点附近的一部分。

(b) 可以手算。设 $\boldsymbol{K} = \{(u,t) : |u| \le t/2\}$，对 (v,w) 要求 $vu + wt \ge 0$ 对所有 $\boldsymbol{K}$ 中的点成立。固定 $t \ge 0$，左端在 $u = \pm t/2$ 中使 vu 为负的那一端最小，最小值是

$$-|v|\frac{t}{2} + wt = t\Big(w - \frac{|v|}{2}\Big).$$

它对所有 $t \ge 0$ 非负，当且仅当 $|v| \le 2w$。$\boldsymbol{K}$ 越窄，需要照顾的方向越少，$\boldsymbol{K}^*$ 就越宽。

下界与证书 第 18章的做法是：把约束乘上乘子加进目标，再对 $\boldsymbol{x}$ 取下确界，得到最优值的下界。这里用同样的计算，只是把“非负乘子”换成“对偶锥中的乘子”。

取 $\boldsymbol{y} \in \mathbb{R}^p$ 和 $\boldsymbol{s} \in \boldsymbol{K}^*$，构造

$$\mathcal{L}(\boldsymbol{x}, \boldsymbol{y}, \boldsymbol{s}) = \boldsymbol{c}^\top \boldsymbol{x} + \boldsymbol{y}^\top(\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}) - \boldsymbol{s}^\top(\boldsymbol{E}\boldsymbol{x} + \boldsymbol{g}).$$

可行的 $\boldsymbol{x}$ 满足 $\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x} = \boldsymbol{0}$，且 $\boldsymbol{s}^\top(\boldsymbol{E}\boldsymbol{x} + \boldsymbol{g}) \ge 0$，所以 $\mathcal{L} \le \boldsymbol{c}^\top \boldsymbol{x}$。

$\mathcal{L}$ 对 $\boldsymbol{x}$ 是仿射的，$\boldsymbol{x}$ 的系数必须为零，下确界才不是 $-\infty$。这个条件是 $\boldsymbol{A}^\top \boldsymbol{y} + \boldsymbol{E}^\top \boldsymbol{s} = \boldsymbol{c}$，此时下确界等于 $\boldsymbol{b}^\top \boldsymbol{y} - \boldsymbol{g}^\top \boldsymbol{s}$。于是得到**锥对偶问题**（conic dual problem）

$$\max_{\boldsymbol{y},\boldsymbol{s}} \ \boldsymbol{b}^\top \boldsymbol{y} - \boldsymbol{g}^\top \boldsymbol{s} \quad \text{s.t.} \quad \boldsymbol{A}^\top \boldsymbol{y} + \boldsymbol{E}^\top \boldsymbol{s} = \boldsymbol{c}, \quad \boldsymbol{s} \in \boldsymbol{K}^*. \tag{20.16}$$

20.1 二次规划
20.2 锥规划
20.2.1 二阶锥规划
20.2.2 半正定规划
20.2.3 锥对偶与证书
20.3 等价改写
20.4 半正定松弛
20.5 模型与求解方法
20.6 本章小结

定理 20.11 锥规划的弱对偶 设 $\boldsymbol{x}$ 是问题 (20.14)的可行点，$(\boldsymbol{y}, \boldsymbol{s})$ 是问题 (20.16)的可行点，则

$$\boldsymbol{c}^{\top}\boldsymbol{x} - (\boldsymbol{b}^{\top}\boldsymbol{y} - \boldsymbol{g}^{\top}\boldsymbol{s}) = \boldsymbol{s}^{\top}(\boldsymbol{E}\boldsymbol{x} + \boldsymbol{g}) \geq 0. \tag{20.17}$$

证明 把 $\boldsymbol{c} = \boldsymbol{A}^{\top}\boldsymbol{y} + \boldsymbol{E}^{\top}\boldsymbol{s}$ 代入 $\boldsymbol{c}^{\top}\boldsymbol{x}$，并用 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$，得到

$$\boldsymbol{c}^{\top}\boldsymbol{x} = \boldsymbol{y}^{\top}\boldsymbol{b} + \boldsymbol{s}^{\top}\boldsymbol{E}\boldsymbol{x}.$$

两边减去 $\boldsymbol{b}^{\top}\boldsymbol{y} - \boldsymbol{g}^{\top}\boldsymbol{s}$，右端成为 $\boldsymbol{s}^{\top}(\boldsymbol{E}\boldsymbol{x} + \boldsymbol{g})$。由 $\boldsymbol{s} \in \boldsymbol{K}^{*}$ 和 $\boldsymbol{E}\boldsymbol{x} + \boldsymbol{g} \in \boldsymbol{K}$，它非负。 ■

式 (20.17)的用法是：手里有一个原始可行点和一个对偶可行点，最优值就被夹在两个目标值之间。若两个值相等，两个点同时最优。这个判断只用到可行性和内积，不需要知道它们是怎么算出来的。

对线性规划，$\boldsymbol{K}^{*} = \mathbb{R}^{n}_{+}$，问题 (20.16)就是第 2章的对偶问题，式 (20.17)就是 $\boldsymbol{s}^{\top}\boldsymbol{x} \geq 0$。

20.2.1 二阶锥规划

“到某点的距离不超过某个值”是最常见的弯曲约束。这一小节要把它写进锥规划，并弄清右端的符号在其中起什么作用。

二阶锥 距离上限的形状是一个圆盘。把半径 t 也当作变量，圆盘就随高度放大，叠起来成为一个圆锥。

定义 20.12 二阶锥规划 集合

$$\boldsymbol{K}^{k+1}_{\mathrm{so}} = \{(\boldsymbol{u}, t) \in \mathbb{R}^{k} \times \mathbb{R} : \|\boldsymbol{u}\|_{2} \leq t\} \tag{20.18}$$

称为二阶锥（second-order cone）。问题

$$\begin{aligned} \min_{\boldsymbol{x}} \quad & \boldsymbol{q}^{\top}\boldsymbol{x} \\ \text{s.t.} \quad & \|\boldsymbol{A}_{i}\boldsymbol{x} + \boldsymbol{b}_{i}\|_{2} \leq \boldsymbol{c}_{i}^{\top}\boldsymbol{x} + d_{i}, \quad i = 1, \dots, m, \\ & \boldsymbol{A}\boldsymbol{x} = \boldsymbol{b} \end{aligned} \tag{20.19}$$

称为二阶锥规划(second-order cone program，SOCP)。这里 $\boldsymbol{A}_{i} \in \mathbb{R}^{k_i \times n}$，$\boldsymbol{b}_{i} \in \mathbb{R}^{k_i}$，$\boldsymbol{c}_{i} \in \mathbb{R}^{n}$，$d_{i} \in \mathbb{R}$。

第 i 条约束说的正是

$$(\boldsymbol{A}_i\boldsymbol{x}+\boldsymbol{b}_i,\ \boldsymbol{c}_i^{\top}\boldsymbol{x}+d_i)\in \boldsymbol{K}_{\mathrm{so}}^{k_i+1}.$$

这个集合确实是闭凸锥。放缩时范数按倍数变化，$\theta\geq 0$ 时仍有 $\|\theta\boldsymbol{u}\|_2\leq \theta t$；相加时由三角不等式，

$$\|\boldsymbol{u}_1+\boldsymbol{u}_2\|_2\leq \|\boldsymbol{u}_1\|_2+\|\boldsymbol{u}_2\|_2\leq t_1+t_2.$$

放缩和相加封闭，合起来就是凸。闭性来自范数连续。

图 20.7画出 $k=2$ 时的二阶锥，高度为 t 的水平截面是半径为 t 的圆盘。

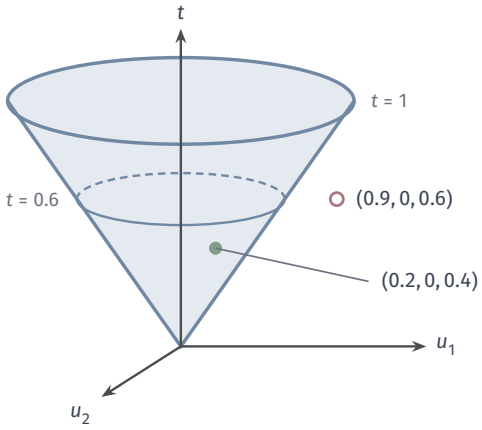


图 20.7　$\mathbb{R}^3$ 中的二阶锥 $\sqrt{u_1^2+u_2^2}\leq t$，画出 $0\leq t\leq 1$ 的部分。绿点 $(0.2,0,0.4)$ 满足 $0.2\leq 0.4$，在锥内。红色空心点 $(0.9,0,0.6)$ 不满足 $0.9\leq 0.6$，在锥外。

右端非负也是条件的一部分　约束的左端是范数，总是非负的，所以满足约束就迫使 $\boldsymbol{c}_i^{\top}\boldsymbol{x}+d_i\geq 0$。这个隐含的符号条件不可丢弃。

有人会想两边平方，把约束写成 $\|\boldsymbol{u}\|_2^2\leq t^2$。这一步改变了集合。正确的等价关系是

$$\|\boldsymbol{u}\|_2\leq t \quad\Longleftrightarrow\quad t\geq 0 \text{ 且} \|\boldsymbol{u}\|_2^2\leq t^2. \tag{20.20}$$

去掉 $t\geq 0$ 后，$(u,t)=(1,-2)$ 满足 $1\leq 4$，却不满足 $1\leq -2$。

图 20.8对比了两个集合。平方之后得到的是上下两片，这个集合甚至不凸。

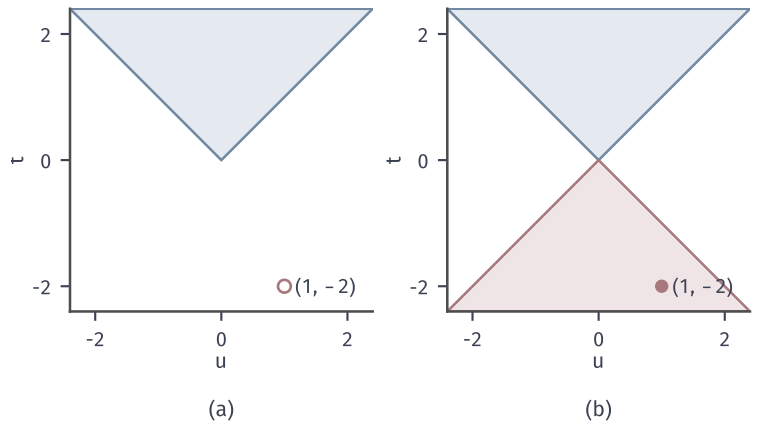


图 20.8 平方丢失符号信息。(a) 二阶锥 $|u| \le t$，点 $(1,-2)$ 不在其中。(b)$u^2 \le t^2$ 的解集多出了红色的下半部分，点 $(1,-2)$ 落在其中，集合不再是凸集。

距离上限的交集 下面用一个能手算的例子看这类可行集。在两个圆盘的公共部分里求最低的点：

$$\min_{\boldsymbol{x}\in\mathbb{R}^2} \; x_2 \quad \text{s.t.} \quad \|\boldsymbol{x}-\boldsymbol{a}_1\|_2 \le 5, \quad \|\boldsymbol{x}-\boldsymbol{a}_2\|_2 \le 5, \tag{20.21}$$

其中 $\boldsymbol{a}_1=(0,0)$，$\boldsymbol{a}_2=(6,0)$。对照式 (20.19)，$\boldsymbol{q}=(0,1)$，$\boldsymbol{A}_i=\boldsymbol{I}$，$\boldsymbol{b}_i=-\boldsymbol{a}_i$，$\boldsymbol{c}_i=\boldsymbol{0}$，$d_i=5$。

每条约束是一个圆盘，二者的交仍是凸集，形状像一枚透镜，如图 20.9所示。它的边界是弯的，所以不是多面体，线性规划和二次规划的可行集都表达不了。

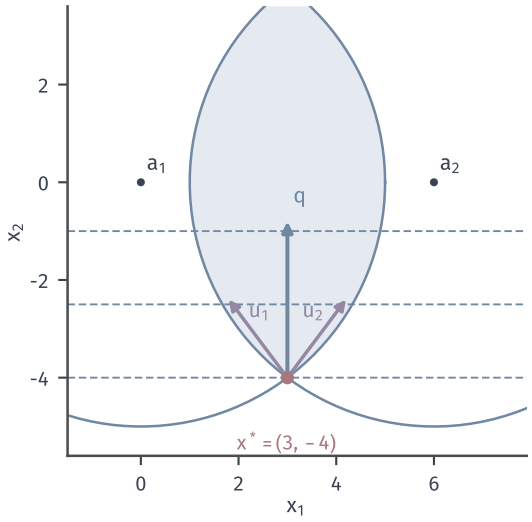


图 20.9 两条距离约束的交集。浅蓝透镜是可行集，蓝色虚线是目标 x_2 的等值线，红点是解 $(3,-4)$。紫色箭头是第 20.2.3小节算出的乘子分量 $\boldsymbol{u}_1,\boldsymbol{u}_2$，蓝色箭头是目标系数 $\boldsymbol{q}=\boldsymbol{u}_1+\boldsymbol{u}_2$，三者同乘 3.2 后画出。

透镜的最低点是两个圆的交点。把两个圆的方程相减，

$$x_1^2 + x_2^2 - (x_1 - 6)^2 - x_2^2 = 0,$$

化简得 $x_1 = 3$。代回第一个圆，得到 $x_2 = \pm 4$。所以候选解是 $(3, -4)$，目标值 -4。它确实最优，稍后用对偶解来证明。

右端含变量 约束右端也可以依赖决策变量。设要找一个位置 $\boldsymbol{x}$，使它到三个站点的最大距离最小。引入变量 t 表示这个最大距离，问题写成

$$\min_{\boldsymbol{x},t} \; t \quad \text{s.t.} \quad \|\boldsymbol{x} - \boldsymbol{p}_i\|_2 \le t, \quad i = 1, 2, 3. \tag{20.22}$$

这里决策变量是 $(\boldsymbol{x}, t) \in \mathbb{R}^3$，每条约束的右端 $\boldsymbol{c}_i^{\mathsf{T}}(\boldsymbol{x}, t) + d_i$ 就是 t。在 $(\boldsymbol{x}, t)$ 空间里，每条约束是一个顶点在 $(\boldsymbol{p}_i, 0)$ 的圆锥，可行集是三个圆锥的交。

取 $\boldsymbol{p}_1 = (0, 0)$，$\boldsymbol{p}_2 = (6, 0)$，$\boldsymbol{p}_3 = (3, 9)$。点 $\boldsymbol{x}^\star = (3, 4)$ 到三个站点的距离都是 5，图 20.10(a) 是相应的覆盖圆。

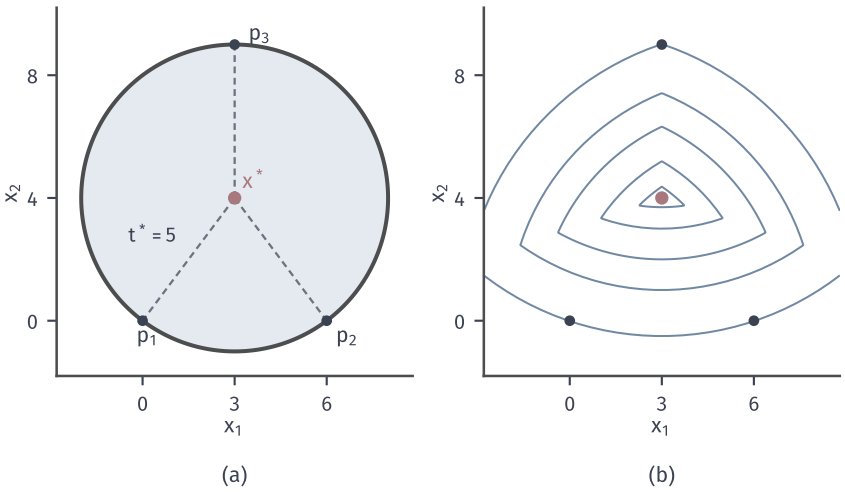


图 20.10 最小化到三个站点的最大距离。(a) 红点到三个站点的距离都等于 $t^\star = 5$，深灰圆是覆盖三点的最小圆。(b) 蓝线是函数 $\max_i \|\boldsymbol{x} - \boldsymbol{p}_i\|_2$ 的等高线，三段圆弧在折角处相接，目标不可微，而写成式 (20.22)后目标和约束都很规则。

下面验证 $\boldsymbol{x}^\star$ 最优。三个站点相对 $\boldsymbol{x}^\star$ 的位置是 $(-3, -4)$、$(3, -4)$、$(0, 5)$，用正权重 $5, 5, 8$ 加权，和为零：

$$5\begin{bmatrix} -3 \\ -4 \end{bmatrix} + 5\begin{bmatrix} 3 \\ -4 \end{bmatrix} + 8\begin{bmatrix} 0 \\ 5 \end{bmatrix} = \mathbf{0}.$$

20.1 二次规划
20.2 锥规划
20.2.1 二阶锥规划
20.2.2 半正定规划
20.2.3 锥对偶与证书
20.3 等价改写
20.4 半正定松弛
20.5 模型与求解方法
20.6 本章小结

所以对任何位移 $\boldsymbol{d} \neq \mathbf{0}$，三个数 $\boldsymbol{d}^{\top}(\boldsymbol{p}_i - \boldsymbol{x}^{\star})$ 不可能全部非负且不全为零；又因三个向量张成平面，它们也不会全为零。因此总有某个 i 使 $\boldsymbol{d}^{\top}(\boldsymbol{p}_i - \boldsymbol{x}^{\star}) < 0$。

对这个 i，位移后的距离满足

$$\|\boldsymbol{x}^{\star} + \boldsymbol{d} - \boldsymbol{p}_i\|_2^2 = 25 + \|\boldsymbol{d}\|_2^2 - 2\boldsymbol{d}^{\top}(\boldsymbol{p}_i - \boldsymbol{x}^{\star}) > 25.$$

最大距离严格变大，所以 $\boldsymbol{x}^{\star}$ 是唯一的最优位置，$t^{\star} = 5$。

20.2.2 半正定规划

有些量天然是矩阵，而且必须像协方差矩阵那样半正定。这一小节回答：矩阵半正定的约束怎样放进锥规划，它能表达哪些条件，又怎样用特征值检验？

矩阵作变量 记 $\mathcal{S}^n$ 为 $n \times n$ 实对称矩阵组成的线性空间。在其上使用**迹内积**（trace inner product）

$$\langle \boldsymbol{X}, \boldsymbol{Y} \rangle = \operatorname{tr}(\boldsymbol{X}\boldsymbol{Y}) = \sum_{i,j} X_{i,j} Y_{i,j}. \tag{20.23}$$

把矩阵按元素排成长向量，这就是普通的欧氏内积。

半正定矩阵的集合记为 $\mathcal{S}_+^n$。$\boldsymbol{X} \in \mathcal{S}_+^n$ 的定义是对所有 $\boldsymbol{v}$ 有 $\boldsymbol{v}^{\top}\boldsymbol{X}\boldsymbol{v} \geq 0$，等价于全部特征值非负，这个等价关系可参考卷二第 6 章“谱分解”。

$\mathcal{S}_+^n$ 是闭凸锥。对固定的 $\boldsymbol{v}$，$\boldsymbol{v}^{\top}\boldsymbol{X}\boldsymbol{v} \geq 0$ 是 $\boldsymbol{X}$ 的一个线性不等式，定义的是过原点的闭半空间。$\mathcal{S}_+^n$ 是无穷多个这样的闭半空间的交，所以它闭、凸，且对非负放缩封闭。

定义 20.13 半正定规划 给定 $\boldsymbol{W}, \boldsymbol{A}_1, \dots, \boldsymbol{A}_m \in \mathcal{S}^n$ 和 $\boldsymbol{b} \in \mathbb{R}^m$，问题

$$\begin{aligned} \min_{\boldsymbol{X} \in \mathcal{S}^n} \quad & \langle \boldsymbol{W}, \boldsymbol{X} \rangle \\ \text{s.t.} \quad & \langle \boldsymbol{A}_i, \boldsymbol{X} \rangle = b_i, \quad i = 1, \dots, m, \\ & \boldsymbol{X} \succeq \mathbf{0} \end{aligned} \tag{20.24}$$

称为**半正定规划**（semidefinite program，SDP）。$\boldsymbol{X} \succeq \mathbf{0}$ 表示 $\boldsymbol{X} \in \mathcal{S}_+^n$。

半正定不是逐元素非负 “$\boldsymbol{X} \succeq \mathbf{0}$”和“$\boldsymbol{X}$ 的元素非负”容易混淆，其实二者互不包含。$\begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}$ 元素全正，特征值却有 -1。$\begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}$ 有负元素，特征值是 0 和 2，半正定。

为了看清这个差别，取迹为 1 的 2×2 对称矩阵

$$\boldsymbol{X}=\begin{bmatrix} a & b \\ b & 1-a \end{bmatrix}.$$

2×2 矩阵半正定，当且仅当两个对角元和行列式都非负。这里就是 $a(1-a)-b^2\geq 0$，配方得到

$$\left(a-\frac{1}{2}\right)^2+b^2\leq\frac{1}{4}.$$

半正定的矩阵组成一个圆盘，而逐元素非负的要求是一条竖带的上半部分，见图 20.11。

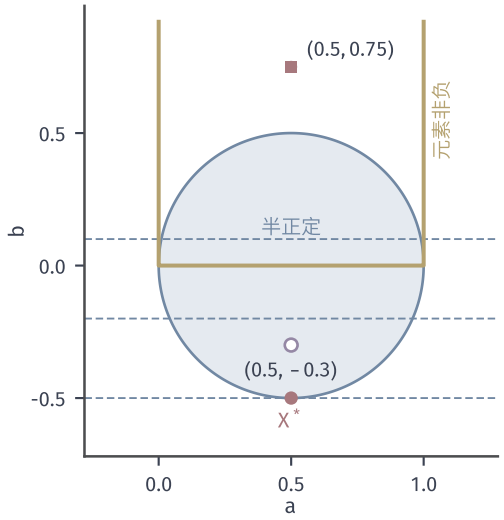


图 20.11　迹为 1 的 2×2 对称矩阵 $\begin{bmatrix} a & b \\ b & 1-a \end{bmatrix}$。浅蓝圆盘是半正定矩阵，黄线围住的是逐元素非负的矩阵。红色方块 $(0.5, 0.75)$ 元素非负但不半正定，紫色空心点 $(0.5, -0.3)$ 半正定但有负元素。蓝色虚线是目标 $2+2b$ 的等值线，红点是最优矩阵 $\boldsymbol{X}^\star$。

可行集的边界是圆，所以半正定规划的最优解一般不在有限个候选的“顶点”上。在这个切片上取 $\boldsymbol{W}=\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$，最小化 $\langle \boldsymbol{W},\boldsymbol{X}\rangle$，约束是 $\operatorname{tr}\boldsymbol{X}=1$、$\boldsymbol{X}\succeq\boldsymbol{0}$。按式 (20.23)计算，

$$\langle \boldsymbol{W},\boldsymbol{X}\rangle = 2a+2b+2(1-a)=2+2b.$$

目标只依赖 b，最小值在圆盘最低点 $(a,b)=(1/2,-1/2)$ 取得，最优值是 1，这正是 $\boldsymbol{W}$ 的最小特征值。最优矩阵是

$$\boldsymbol{X}^\star=\frac{1}{2}\begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}.$$

线性矩阵不等式 实际问题常把变量放在矩阵的元素上，得到下面的约束：

$$\boldsymbol{F}_0 + x_1\boldsymbol{F}_1 + \cdots + x_n\boldsymbol{F}_n \succeq \boldsymbol{0}, \tag{20.25}$$

其中 $\boldsymbol{F}_j \in \mathcal{S}^k$。这称为**线性矩阵不等式**（linear matrix inequality，LMI）。它正是式 (20.14)中取 $\boldsymbol{K} = \mathcal{S}^k_+$ 的情形，$\boldsymbol{E}\boldsymbol{x}+\boldsymbol{g}$ 是 $\boldsymbol{x}$ 的仿射函数，取值为矩阵。

一条线性矩阵不等式可以表达弯曲的集合。例如

$$\boldsymbol{F}(\boldsymbol{x}) = \begin{bmatrix} 1+x_1 & x_2 \\ x_2 & 1-x_1 \end{bmatrix}$$

的特征值是 $1 \pm \|\boldsymbol{x}\|_2$，所以 $\boldsymbol{F}(\boldsymbol{x}) \succeq \boldsymbol{0}$ 恰好是单位圆盘。

检验一个点是否可行，只需算特征值。取 $\boldsymbol{x} = (0.6, 0.6)$，特征值约为 0.152 和 1.849，都为正，可行。取 $\boldsymbol{x} = (0.8, 0.8)$，最小特征值约为 -0.131，不可行。图 20.12(a) 画出这两个点。

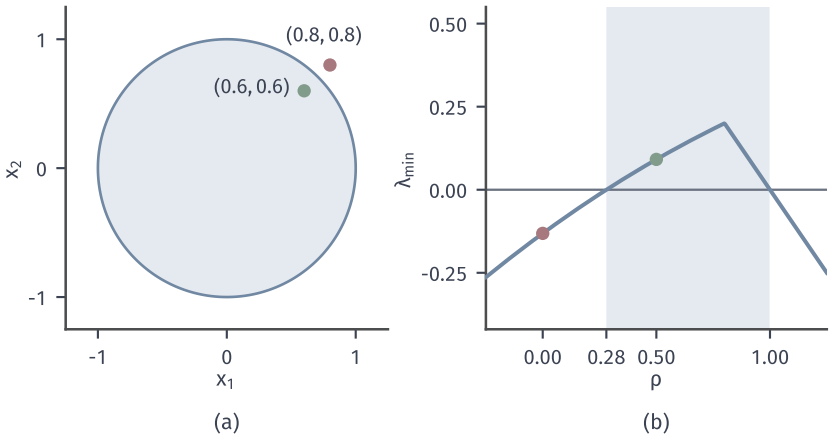


图 20.12 用特征值检验线性矩阵不等式。(a)$\boldsymbol{F}(\boldsymbol{x}) \succeq \boldsymbol{0}$ 的解集是单位圆盘，绿点可行，红点不可行。(b) 相关矩阵 (20.26)的最小特征值随 ρ 的变化，浅蓝区间 $[0.28, 1]$ 是使矩阵半正定的 ρ。绿点 $\rho = 0.5$ 可行，红点 $\rho = 0$ 不可行。

协方差约束 线性矩阵不等式的一个典型来源是协方差矩阵必须半正定。设三个量两两的相关系数中，已知 $\rho_{1,2} = \rho_{2,3} = 0.8$，问 $\rho_{1,3} = \rho$ 能取哪些值。相关矩阵是

$$\boldsymbol{R}(\rho) = \begin{bmatrix} 1 & 0.8 & \rho \\ 0.8 & 1 & 0.8 \\ \rho & 0.8 & 1 \end{bmatrix}. \tag{20.26}$$

协方差矩阵半正定这一事实的来源可参考卷七第 2 章“随机向量与联合分布”。这里只用到结论：$\boldsymbol{R}(\rho)$ 不半正定，就不存在这样的三个随机变量。

取 $\rho = 0$，矩阵的元素都非负，特征值却约为 -0.131、1 和 2.131。所以 $\rho = 0$ 不可能，1 与 2 强相关、2 与 3 强相关时，1 与 3 不能不相关。

取 $\rho = 0.5$，特征值约为 0.091、0.5 和 2.409，可行。一般地，

$$\det \boldsymbol{R}(\rho) = -(\rho - 1)(\rho - 0.28),$$

结合 $|\rho| \le 1$ 可知可行范围是 $0.28 \le \rho \le 1$，与图 20.12(b) 一致。

谱上界 另一类重要的表达能力是控制特征值。设对称矩阵 $\boldsymbol{B}(\boldsymbol{x})$ 仿射地依赖 $\boldsymbol{x}$。对谱分解后的每个特征值看，$\lambda_{\max}(\boldsymbol{B}(\boldsymbol{x})) \le t$ 等价于 $t\boldsymbol{I} - \boldsymbol{B}(\boldsymbol{x})$ 的特征值全部非负，即

$$\lambda_{\max}(\boldsymbol{B}(\boldsymbol{x})) \le t \quad \Longleftrightarrow \quad t\boldsymbol{I} - \boldsymbol{B}(\boldsymbol{x}) \succeq \boldsymbol{0}. \tag{20.27}$$

所以最小化最大特征值可以写成半正定规划：在式 (20.27)的约束下最小化 t。

看一个具体的例子：

$$\boldsymbol{B}(x) = \begin{bmatrix} 1 + x & 1 \\ 1 & 3 - x \end{bmatrix}.$$

它的特征值是 $2 \pm \sqrt{(1-x)^2 + 1}$，所以 $\lambda_{\max}$ 在 $x = 1$ 取最小值 3。这是一个光滑例子，但 $\lambda_{\max}$ 在特征值重合处通常不可微，而写成式 (20.27)后，非光滑性消失在锥约束里。图 20.13画出这个例子，图中的紫线下一小节解释。

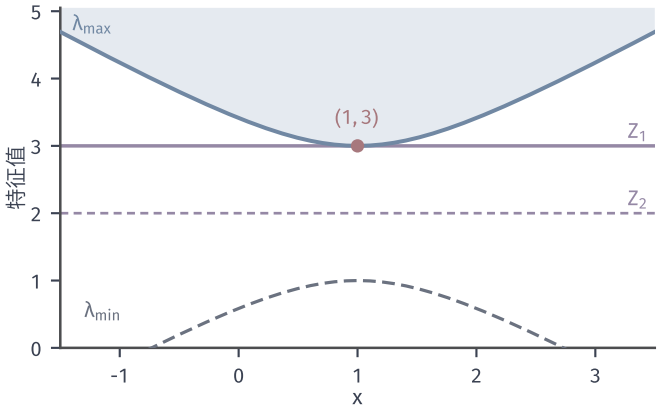


图 20.13 $\boldsymbol{B}(x)$ 的两个特征值。浅蓝区域是 $\lambda_{\max}(\boldsymbol{B}(x)) \le t$ 的 (x, t)，红点是最优解。紫色实线 Z_1 是由 $\boldsymbol{Z}_1 = \frac{1}{2}\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$ 给出的下界 3，紫色虚线 Z_2 是由 $\boldsymbol{Z}_2 = \frac{1}{2}\boldsymbol{I}$ 给出的下界 2。

20.1 二次规划
20.2 锥规划
20.2.1 二阶锥规划
20.2.2 半正定规划
20.2.3 锥对偶与证书
20.3 等价改写
20.4 半正定松弛
20.5 模型与求解方法
20.6 本章小结

20.2.3 锥对偶与证书

对偶问题 (20.16)要用到 $\boldsymbol{K}^*$。这一小节算出三种常用锥的对偶锥，写出对应的对偶问题，再说明弱对偶可以放心使用，而强对偶需要额外的条件。

自对偶性 下面的定理说，这三种锥的乘子就在原来的锥里取。

定理 20.14 三种常用锥的自对偶性 $\mathbb{R}^n_+$、$\boldsymbol{K}^{k+1}_{\mathrm{so}}$ 和 $\mathcal{S}^n_+$ 的对偶锥都是它们自身。其中 $\mathcal{S}^n_+$ 的内积取迹内积。

证明 非负象限。若 $\boldsymbol{s} \geq \boldsymbol{0}$，对 $\boldsymbol{x} \geq \boldsymbol{0}$ 有 $\boldsymbol{s}^{\top}\boldsymbol{x} \geq 0$。反过来，若 $s_i < 0$，取 $\boldsymbol{x} = \boldsymbol{e}_i$ 得 $\boldsymbol{s}^{\top}\boldsymbol{x} < 0$。

二阶锥。设 $(\boldsymbol{v}, w)$、$(\boldsymbol{u}, t)$ 都在二阶锥中。由 Cauchy–Schwarz 不等式，

$$\boldsymbol{v}^{\top}\boldsymbol{u} + wt \geq -\|\boldsymbol{v}\|_2\|\boldsymbol{u}\|_2 + wt \geq -wt + wt = 0.$$

所以二阶锥包含于它的对偶锥。

反过来，设 $(\boldsymbol{v}, w)$ 在对偶锥中。取 $(\boldsymbol{u}, t) = (\boldsymbol{0}, 1)$，得 $w \geq 0$。若 $\boldsymbol{v} \neq \boldsymbol{0}$，取 $\boldsymbol{u} = -\boldsymbol{v}/\|\boldsymbol{v}\|_2$、$t = 1$，得到 $-\|\boldsymbol{v}\|_2 + w \geq 0$。这两种情形都给出 $\|\boldsymbol{v}\|_2 \leq w$。

半正定锥。设 $\boldsymbol{X}, \boldsymbol{S} \succeq \boldsymbol{0}$，由谱分解取半正定平方根，

$$\langle \boldsymbol{S}, \boldsymbol{X} \rangle = \operatorname{tr}(\boldsymbol{S}^{1/2}\boldsymbol{X}\boldsymbol{S}^{1/2}) \geq 0,$$

因为 $\boldsymbol{S}^{1/2}\boldsymbol{X}\boldsymbol{S}^{1/2}$ 半正定，迹就是非负特征值之和。

反过来，设 $\boldsymbol{S}$ 在对偶锥中。对任意 $\boldsymbol{v}$，取 $\boldsymbol{X} = \boldsymbol{v}\boldsymbol{v}^{\top} \succeq \boldsymbol{0}$，得到

$$\langle \boldsymbol{S}, \boldsymbol{v}\boldsymbol{v}^{\top} \rangle = \boldsymbol{v}^{\top}\boldsymbol{S}\boldsymbol{v} \geq 0,$$

所以 $\boldsymbol{S} \succeq \boldsymbol{0}$。 ■

半正定锥的乘子是半正定矩阵，不是元素非负的矩阵；二阶锥的乘子也有分量可以为负。线性规划里“乘子非负”这句话，推广之后是“乘子属于对偶锥”。

写出对偶问题 把定理 20.14代入式 (20.16)。对二阶锥规划 (20.19)，每条约束对应乘子 $(\boldsymbol{u}_i, \tau_i)$，等式的乘子记作 $\boldsymbol{y}$。按定义逐项写出，对偶问题是

$$\begin{aligned} \max \quad & \boldsymbol{b}^{\top}\boldsymbol{y} - \sum_{i=1}^{m}(\boldsymbol{b}_i^{\top}\boldsymbol{u}_i + d_i\tau_i) \\ \text{s.t.} \quad & \boldsymbol{A}^{\top}\boldsymbol{y} + \sum_{i=1}^{m}(\boldsymbol{A}_i^{\top}\boldsymbol{u}_i + \tau_i\boldsymbol{c}_i) = \boldsymbol{q}, \\ & \|\boldsymbol{u}_i\|_2 \le \tau_i, \quad i = 1, \dots, m. \end{aligned} \tag{20.28}$$

半正定规划 (20.24)中 $\boldsymbol{X}$ 本身属于锥，相当于 $\boldsymbol{E}$ 是恒等映射、$\boldsymbol{g} = \boldsymbol{0}$，对偶问题是

$$\max_{\boldsymbol{y},\boldsymbol{S}} \ \boldsymbol{b}^{\top}\boldsymbol{y} \quad \text{s.t.} \quad \sum_{i=1}^{m} y_i\boldsymbol{A}_i + \boldsymbol{S} = \boldsymbol{W}, \quad \boldsymbol{S} \succeq \boldsymbol{0}. \tag{20.29}$$

相应的间隙公式是

$$\langle \boldsymbol{W}, \boldsymbol{X} \rangle - \boldsymbol{b}^{\top}\boldsymbol{y} = \langle \boldsymbol{S}, \boldsymbol{X} \rangle. \tag{20.30}$$

示例 20.15 透镜问题的对偶证书 对问题 (20.21)，式 (20.28)成为：在 $\boldsymbol{u}_1 + \boldsymbol{u}_2 = \boldsymbol{q}$、$\|\boldsymbol{u}_i\|_2 \le \tau_i$ 下最大化

$$\boldsymbol{a}_1^{\top}\boldsymbol{u}_1 + \boldsymbol{a}_2^{\top}\boldsymbol{u}_2 - 5\tau_1 - 5\tau_2.$$

先任取一个可行的乘子，看它给出什么下界。取 $\boldsymbol{u}_1 = \boldsymbol{u}_2 = (0, 1/2)$，$\tau_1 = \tau_2 = 1/2$，对偶目标是 -5。所以无论可行点是什么，$x_2 \ge -5$，这个下界对，但不紧。

要使间隙为零，由式 (20.17)，每条约束的 $(\boldsymbol{u}_i, \tau_i)$ 必须与 $(\boldsymbol{x}^{\star} - \boldsymbol{a}_i, 5)$ 内积为零。两个向量都在二阶锥的边界上时，这要求 $\boldsymbol{u}_i$ 与 $\boldsymbol{x}^{\star} - \boldsymbol{a}_i$ 反向，且 $\|\boldsymbol{u}_i\|_2 = \tau_i$。

在 $\boldsymbol{x}^{\star} = (3, -4)$ 处，这给出

$$\boldsymbol{u}_1 = \tau_1 \begin{bmatrix} -3/5 \\ 4/5 \end{bmatrix}, \qquad \boldsymbol{u}_2 = \tau_2 \begin{bmatrix} 3/5 \\ 4/5 \end{bmatrix}.$$

再由 $\boldsymbol{u}_1 + \boldsymbol{u}_2 = (0, 1)$，解得

$$\tau_1 = \tau_2 = \frac{5}{8}, \qquad \boldsymbol{u}_1 = \begin{bmatrix} -3/8 \\ 1/2 \end{bmatrix}, \qquad \boldsymbol{u}_2 = \begin{bmatrix} 3/8 \\ 1/2 \end{bmatrix}.$$

对偶目标是

$$0 + \frac{18}{8} - \frac{25}{8} - \frac{25}{8} = -4.$$

它等于原始目标值，所以 $(3,-4)$ 最优，这对乘子也最优。图 20.9中的紫色箭头画的就是 $\boldsymbol{u}_1,\boldsymbol{u}_2$，二者之和是目标的梯度。

示例 20.16　谱上界的对偶证书　对 $\min t$、$t\boldsymbol{I}-\boldsymbol{B}(x)\succeq\boldsymbol{0}$，取乘子 $\boldsymbol{Z}\succeq\boldsymbol{0}$。不必套公式，直接从谱上界出发：任何 $\operatorname{tr}\boldsymbol{Z}=1$ 的 $\boldsymbol{Z}\succeq\boldsymbol{0}$ 都满足

$$\lambda_{\max}(\boldsymbol{B}(x))\geq\langle\boldsymbol{Z},\boldsymbol{B}(x)\rangle,$$

因为 $\lambda_{\max}\boldsymbol{I}-\boldsymbol{B}(x)\succeq\boldsymbol{0}$ 与 $\boldsymbol{Z}$ 的迹内积非负。

若再选 $\boldsymbol{Z}$ 使右端不含 x，就得到一个对所有 x 成立的常数下界。$\boldsymbol{B}(x)$ 中 x 的系数是 $\operatorname{diag}(1,-1)$，所以要求 $Z_{1,1}=Z_{2,2}$，再由迹为 1 得 $Z_{1,1}=Z_{2,2}=1/2$。取 $Z_{1,2}=1/2$，得到

$$\boldsymbol{Z}_1=\frac{1}{2}\begin{bmatrix}1&1\\1&1\end{bmatrix},\qquad\langle\boldsymbol{Z}_1,\boldsymbol{B}(x)\rangle=\frac{1}{2}(1+x+2+3-x)=3.$$

变量 x 消掉了，于是 $\lambda_{\max}(\boldsymbol{B}(x))\geq 3$ 对所有 x 成立。$x=1$ 时取等，这就是最优性的证明，即图 20.13的紫色实线。

取 $Z_{1,2}=0$，同样的计算给出常数 2，下界正确但不紧，是图中的紫色虚线。

矩阵互补　式 (20.17)说明，零间隙等价于 $\boldsymbol{s}^{\mathsf{T}}(\boldsymbol{E}\boldsymbol{x}+\boldsymbol{g})=0$，这是互补松弛的锥形式。半正定时，这个条件比一个数等于零更强。

设 $\boldsymbol{X},\boldsymbol{S}\succeq\boldsymbol{0}$ 且 $\langle\boldsymbol{S},\boldsymbol{X}\rangle=0$，则

$$\operatorname{tr}(\boldsymbol{S}^{1/2}\boldsymbol{X}\boldsymbol{S}^{1/2})=\|\boldsymbol{X}^{1/2}\boldsymbol{S}^{1/2}\|_{\mathrm{F}}^2=0.$$

所以 $\boldsymbol{X}^{1/2}\boldsymbol{S}^{1/2}=\boldsymbol{0}$，再两边分别乘 $\boldsymbol{X}^{1/2}$ 和 $\boldsymbol{S}^{1/2}$，得到

$$\boldsymbol{X}\boldsymbol{S}=\boldsymbol{0}. \tag{20.31}$$

二者的列空间互相正交，秩之和不超过 n。

以迹为 1 的例子验证。对偶问题是 $\max y$、$\boldsymbol{S}=\boldsymbol{W}-y\boldsymbol{I}\succeq\boldsymbol{0}$，最优值在 $y=\lambda_{\min}(\boldsymbol{W})=1$ 取得。这时

$$\boldsymbol{S}=\begin{bmatrix}1&1\\1&1\end{bmatrix},\qquad\boldsymbol{X}^{\star}\boldsymbol{S}=\frac{1}{2}\begin{bmatrix}1&-1\\-1&1\end{bmatrix}\begin{bmatrix}1&1\\1&1\end{bmatrix}=\boldsymbol{0}.$$

强对偶需要条件 弱对偶无条件成立，证书就是这么来的。但两个目标值是否一定能碰到一起？线性规划中，只要原始和对偶都可行，最优值就相等且都能取到。这一结论不能原样推广。

类似第 18章的 Slater 条件，锥规划也有严格可行性的条件。若存在满足 $\boldsymbol{Ax}=\boldsymbol{b}$ 且 $\boldsymbol{Ex}+\boldsymbol{g}\in\operatorname{int}\boldsymbol{K}$ 的点，并且原始最优值有限，则对偶问题取得最优解，且间隙为零。把原始和对偶的角色对调，结论同样成立。证明用凸集分离定理，与 Slater 条件的论证相同，只是把标量不等式换成锥成员条件，读者可查阅凸优化教材[2]。

[2] S. Boyd, L. Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004

下面两个例子说明缺少这一条件时会出什么问题。

示例 20.17 最优值取不到 考虑

$$\min_{\boldsymbol{x}} \; x_1 \quad \text{s.t.} \quad \begin{bmatrix} x_1 & 1 \\ 1 & x_2 \end{bmatrix} \succeq \mathbf{0}.$$

约束等价于 $x_1, x_2 > 0$ 且 $x_1 x_2 \geq 1$，可行集是双曲线上方的区域，如图 20.14(a) 所示。取 $x_1 = 1/k$、$x_2 = k$，目标趋于 0，但 $x_1 = 0$ 不可行，最优值 0 取不到。

把式 (20.16)写出来：$\boldsymbol{Z}\succeq\mathbf{0}$，$Z_{1,1}=1$，$Z_{2,2}=0$，目标是 $-2Z_{1,2}$。半正定和 $Z_{2,2}=0$ 迫使 $Z_{1,2}=0$，对偶唯一的可行值是 0，它取到了。

这里原始严格可行（取 $x_1=x_2=2$），所以对偶取得最优且间隙为零，符合上面的结论。对偶没有严格可行点，所以原始不保证取得最优解。

示例 20.18 正的对偶间隙 考虑

$$\min_{\boldsymbol{x}} \; x_1 \quad \text{s.t.} \quad \begin{bmatrix} 0 & x_1 & 0 \\ x_1 & x_2 & 0 \\ 0 & 0 & x_1+1 \end{bmatrix} \succeq \mathbf{0}.$$

半正定矩阵的对角元为零时，同行同列都为零，所以 $x_1=0$，$p^\star=0$。

对偶问题的乘子 $\boldsymbol{Z}\succeq\mathbf{0}$ 要满足两个条件。x_2 的系数给出 $Z_{2,2}=0$，从而 $Z_{1,2}=0$。x_1 的系数给出 $2Z_{1,2}+Z_{3,3}=1$，从而 $Z_{3,3}=1$。

对偶目标是 $-Z_{3,3}=-1$，所以 $d^\star=-1$。原始和对偶都可行，也都取到最优值，二者却相差 1，见图 20.14(b)。原始可行集的矩阵全部奇异，严格可行性不成立。

20.1 二次规划
20.2 锥规划
20.3 等价改写
20.3.1 上图形式
20.3.2 Schur 补改写
20.4 半正定松弛
20.5 模型与求解方法
20.6 本章小结

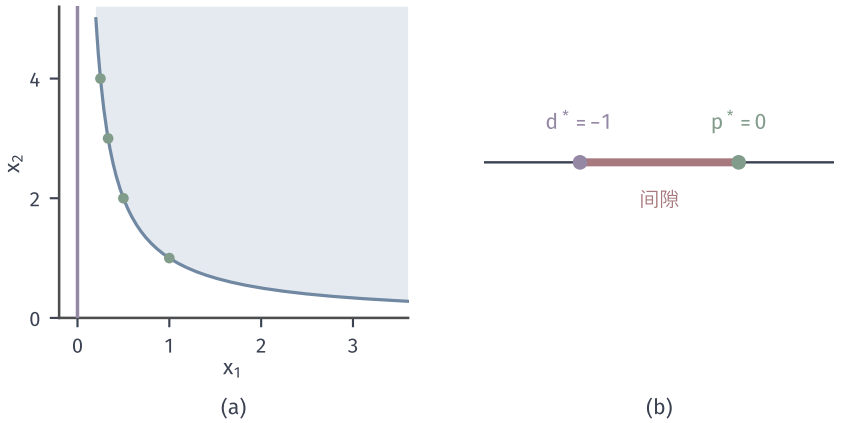


图 20.14 半正定规划强对偶失效的两种方式。(a) 浅蓝区域是可行集 $x_1 x_2 \geq 1$，绿点 $(1/k, k)$ 的目标趋于紫线 $x_1 = 0$，但永远到不了。(b) 原始最优值 0（绿）与对偶最优值 -1（紫）之间有正间隙（红）。

这些现象的根源在于，闭凸锥在线性映射下的像不一定闭。非负象限是多面体，多面体的线性像仍是闭集，二阶锥和半正定锥则没有这个保证。表 20.5归纳了差别。

性质	线性规划	一般锥规划
弱对偶	成立	成立
两边可行时间隙为零	成立	不一定
最优值能取到	有限时取到	不一定
零间隙的依据	无需额外条件	严格可行性等条件

表 20.5 线性规划与一般锥规划的对偶性质对比。

所以报告半正定规划的结果时，弱对偶给出的界永远可靠；“间隙为零”这句话则要么由算出的两个可行解直接验证，要么先核对严格可行性。

20.3 等价改写

实际问题很少一开始就长成式 (20.2)或式 (20.14)的样子，常要引入辅助变量才能写进去。这就需要回答：引入辅助变量、换了约束之后，凭什么说问题没有变？

什么叫没有改变问题 设原问题是在 $\mathcal{C}$ 上最小化 $f(\boldsymbol{x})$，改写后的问题是在 $\mathcal{C}'$ 上最小化 $\phi(\boldsymbol{x}, \boldsymbol{z})$，其中 $\boldsymbol{z}$ 是辅助变量。要说二者等价，需要两个方向的对应。

定义 20.19 等价改写 若下面两条都成立，则称改写后的问题是原问题的**等价改写**（equivalent reformulation）：

1. 对每个 $\boldsymbol{x} \in \boldsymbol{C}$，存在 $\boldsymbol{z}$ 使 $(\boldsymbol{x}, \boldsymbol{z}) \in \boldsymbol{C}'$，且 $\phi(\boldsymbol{x}, \boldsymbol{z}) \le f(\boldsymbol{x})$；
2. 对每个 $(\boldsymbol{x}, \boldsymbol{z}) \in \boldsymbol{C}'$，都有 $\boldsymbol{x} \in \boldsymbol{C}$，且 $f(\boldsymbol{x}) \le \phi(\boldsymbol{x}, \boldsymbol{z})$。

第一条说原问题的每个候选都有替身，而且替身的代价不更高。第二条说消去辅助变量后回到的正是原约束，代价也没有被低估。

定理 20.20 等价改写保持最优值与最优解 在定义 20.19的条件下，两个问题的最优值相等。若 $(\boldsymbol{x}^\star, \boldsymbol{z}^\star)$ 是改写问题的最优解，则 $\boldsymbol{x}^\star$ 是原问题的最优解。若 $\boldsymbol{x}^\star$ 是原问题的最优解，则它配上第一条中的 $\boldsymbol{z}$ 是改写问题的最优解。

证明 记两个最优值为 p 和 p'。第一条说明，原问题的每个目标值都不低于改写问题的某个目标值，于是 $p' \le p$。第二条同理给出 $p \le p'$，所以 $p = p'$。

设 $(\boldsymbol{x}^\star, \boldsymbol{z}^\star)$ 最优。第二条给出 $\boldsymbol{x}^\star \in \boldsymbol{C}$，以及

$$f(\boldsymbol{x}^\star) \le \phi(\boldsymbol{x}^\star, \boldsymbol{z}^\star) = p' = p.$$

所以 $\boldsymbol{x}^\star$ 最优。

设 $\boldsymbol{x}^\star$ 最优，取第一条中的 $\boldsymbol{z}$。则 $(\boldsymbol{x}^\star, \boldsymbol{z})$ 可行，且

$$\phi(\boldsymbol{x}^\star, \boldsymbol{z}) \le f(\boldsymbol{x}^\star) = p = p'.$$

所以它最优。 ■

定理同时给出了恢复原变量的办法：解改写问题，然后把辅助变量丢掉。对照图 20.15(a)，改写后的可行集沿辅助变量方向投影，恰好覆盖原可行集。

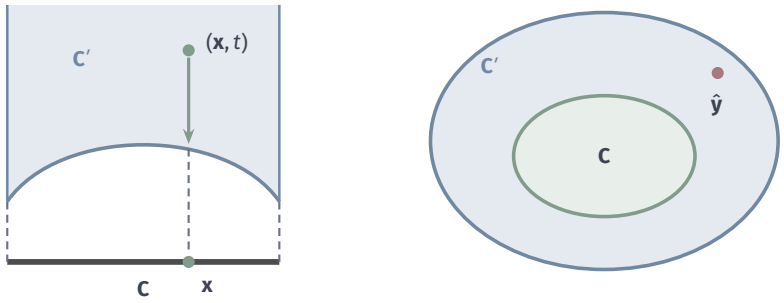


图 20.15 等价改写与松弛的区别。(a) 等价改写：点 $(\boldsymbol{x}, t)$ 沿竖直方向下移不增加代价，投影后回到 $\boldsymbol{C}$，$\boldsymbol{C}'$ 的投影恰是 $\boldsymbol{C}$（深灰线段）。(b) 松弛：$\boldsymbol{C}'$ 严格包含 $\boldsymbol{C}$，$\boldsymbol{C}'$ 中可能有红点 $\hat{\boldsymbol{y}}$ 这样不对应任何原可行点的元素，所以只保留定义中的第一条。

若只有第一条成立，得到的是另一种东西：改写后的问题最优值不超过原问题，但它的解可能不对应任何原可行点。这就是图中的 (b)，留到第 20.4节讨论。

20.3.1 上图形式

目标是非线性函数时，能否把非线性移到约束里，使目标变成线性的？这一小节用范数和凸二次两种目标回答这个问题。

范数目标 函数 f 的**上图**（epigraph）是它图像上方的点集 $\{(\boldsymbol{x}, t) : f(\boldsymbol{x}) \le t\}$。最小化 f，就是在上图中寻找最低的点。

对 $\min \|\boldsymbol{D}\boldsymbol{x} - \boldsymbol{r}\|_2$，引入 t，写成

$$\min_{\boldsymbol{x}, t} \ t \quad \text{s.t.} \quad \|\boldsymbol{D}\boldsymbol{x} - \boldsymbol{r}\|_2 \le t. \tag{20.32}$$

目标成了线性函数，约束是一条二阶锥约束。

核对定义 20.19。对任意 $\boldsymbol{x}$，取 $t = \|\boldsymbol{D}\boldsymbol{x} - \boldsymbol{r}\|_2$，可行，代价相等，第一条成立。对任意可行的 $(\boldsymbol{x}, t)$，$\|\boldsymbol{D}\boldsymbol{x} - \boldsymbol{r}\|_2 \le t$，第二条成立。

最优时约束取等号：若 $t > \|\boldsymbol{D}\boldsymbol{x} - \boldsymbol{r}\|_2$，把 t 减小到等号处仍可行，目标更低。图 20.16(a) 中的绿色箭头就是这个下移。

20.1 二次规划
20.2 锥规划
20.3 等价改写
20.3.1 上图形式
20.3.2 Schur 补改写
20.4 半正定松弛
20.5 模型与求解方法
20.6 本章小结

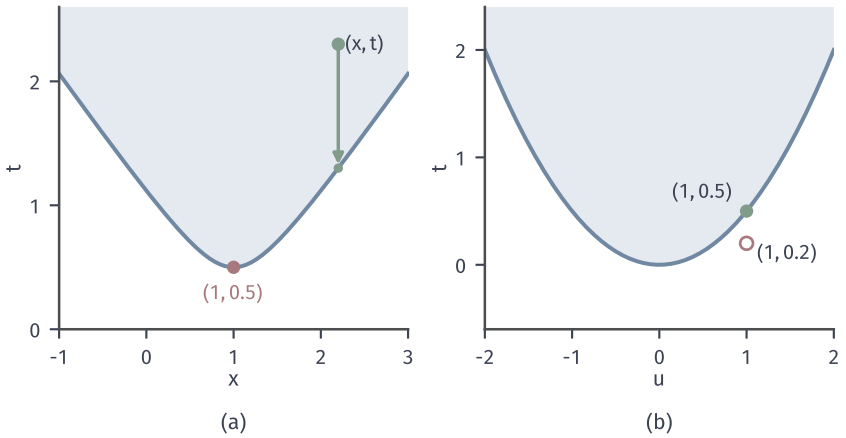


图 20.16　上图改写。(a)$f(x) = \|(x-1, 1/2)\|_2$ 的上图（浅蓝），绿点下移到函数图像上时 t 减小而 x 不变，红点是上图中的最低点。(b) 在网格上逐点判定 $\|(2u, 2t-1)\|_2 \le 2t+1$，浅蓝区域恰是抛物线 $t \ge u^2/2$ 的上方，绿点 $(1, 0.5)$ 在边界上，红色空心点 $(1, 0.2)$ 不满足约束。

凸二次目标　平方范数多了一层：$\frac{1}{2}\boldsymbol{x}^\top \boldsymbol{Q}\boldsymbol{x} \le t$ 的左端是二次的，不是范数。这需要两步转换。

第一步是分解。$\boldsymbol{Q} \succeq \boldsymbol{0}$ 时存在 $\boldsymbol{F} \in \mathbb{R}^{k\times n}$ 使 $\boldsymbol{Q} = \boldsymbol{F}^\top \boldsymbol{F}$，例如取 Cholesky 因子或由谱分解得到。最小二乘中直接有 $\boldsymbol{F} = \boldsymbol{D}$。于是上图约束是 $\|\boldsymbol{F}\boldsymbol{x}\|_2^2 \le 2t$。

第二步把“平方范数不超过乘积”写成二阶锥。

引理 20.21　旋转二阶锥　对 $\boldsymbol{u} \in \mathbb{R}^k$ 和 $s, w \in \mathbb{R}$，

$$\|\boldsymbol{u}\|_2^2 \le sw,\quad s \ge 0,\quad w \ge 0 \iff \left\| \begin{bmatrix} 2\boldsymbol{u} \\ s - w \end{bmatrix} \right\|_2 \le s + w. \tag{20.33}$$

证明　先证从左到右。由 $\|\boldsymbol{u}\|_2^2 \le sw$，

$$4\|\boldsymbol{u}\|_2^2 + (s-w)^2 \le 4sw + (s-w)^2 = (s+w)^2.$$

又 $s + w \ge 0$，两边开方得到右式。

再证从右到左。右式的范数不小于 $|s-w|$，所以 $s + w \ge |s-w|$。分别取绝对值的两种符号，得到 $w \ge 0$ 和 $s \ge 0$。把右式平方，同样的展开给出 $4\|\boldsymbol{u}\|_2^2 \le 4sw$。 ■

取 $\boldsymbol{u}=\boldsymbol{F}\boldsymbol{x}$、$s=2t$、$w=1$，就得到 $\|\boldsymbol{F}\boldsymbol{x}\|_2^2\le 2t$ 的二阶锥形式。凸二次规划 (20.2)因而等价于

$$\begin{aligned}\min_{\boldsymbol{x},t}\quad & t+\boldsymbol{q}^{\top}\boldsymbol{x}\\ \text{s.t.}\quad & \left\|\begin{bmatrix}2\boldsymbol{F}\boldsymbol{x}\\ 2t-1\end{bmatrix}\right\|_2\le 2t+1,\\ & \boldsymbol{A}\boldsymbol{x}=\boldsymbol{b},\quad \boldsymbol{G}\boldsymbol{x}\le\boldsymbol{h}.\end{aligned}\tag{20.34}$$

图 20.16(b) 用网格判定的方式核对了 $k=1$ 的情形：约束 $\|(2u,2t-1)\|_2\le 2t+1$ 的解集正好是 $t\ge u^2/2$。

再用定义 20.19核对。第一条取 $t=\frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{Q}\boldsymbol{x}$。第二条由引理得到 $t\ge\frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{Q}\boldsymbol{x}$，于是原目标不超过改写后的目标。恢复 $\boldsymbol{x}$ 时丢弃 t 即可。

示例 20.22　预算问题的二阶锥形式　预算问题的目标是 $\frac{1}{2}\|\boldsymbol{D}\boldsymbol{x}-\boldsymbol{r}\|_2^2$，这里取 $\boldsymbol{u}=\boldsymbol{D}\boldsymbol{x}-\boldsymbol{r}$，约束写成

$$\left\|\begin{bmatrix}2(\boldsymbol{D}\boldsymbol{x}-\boldsymbol{r})\\ 2t-1\end{bmatrix}\right\|_2\le 2t+1.$$

在 $\boldsymbol{x}^{\star}=(3/2,1/2)$ 处，残差是 $(-2,1/2,1/2)$，取 $t=9/4$。左端向量是 $(-4,1,1,7/2)$，长度的平方是

$$16+1+1+\frac{49}{4}=\frac{121}{4}.$$

所以左端等于 $11/2$，右端也等于 $2t+1=11/2$。约束取等号，改写问题的目标值 $t=9/4$ 与原问题的 $f^{\star}$ 相同。

只有 $\boldsymbol{Q}\succeq\boldsymbol{0}$ 时才有实分解 $\boldsymbol{Q}=\boldsymbol{F}^{\top}\boldsymbol{F}$。第 20.1.3小节的 $\operatorname{diag}(1,-1)$ 没有这样的分解，也不可能写成式 (20.34)：二阶锥规划的可行集是凸的，而目标的上图不凸。

另外，若目标是 $\min\|\boldsymbol{D}\boldsymbol{x}-\boldsymbol{r}\|_2^2$，也可以直接最小化不带平方的范数。平方在非负数上严格递增，所以两者最优解相同；但最优值不同，这与定义 20.19的“最优值相等”不是一回事，恢复目标值时要重新平方。

维数与成本　增加变量并不自动带来计算上的好处。表 20.6比较凸二次目标的两种写法，$\boldsymbol{Q}=\boldsymbol{F}^{\top}\boldsymbol{F}$，$\boldsymbol{F}\in\mathbb{R}^{k\times n}$。

20.1 二次规划
20.2 锥规划
20.3 等价改写
20.3.1 上图形式
20.3.2 Schur 补改写
20.4 半正定松弛
20.5 模型与求解方法
20.6 本章小结

	二次规划形式	二阶锥形式
变量个数	n	$n+1$
非线性结构	目标中的 $\boldsymbol{Q}$	一个 $k+2$ 维的二阶锥
需要的准备	$\boldsymbol{Q}$ 或矩阵向量积	分解 $\boldsymbol{F}$
可用的方法	二次规划专用方法	通用锥规划方法

表 20.6 同一凸二次目标的两种写法。

$\boldsymbol{Q}$ 稀疏时，分解因子 $\boldsymbol{F}$ 可能比 $\boldsymbol{Q}$ 稠密得多，改写后存储反而增加。$\boldsymbol{Q}$ 只能通过矩阵向量积访问时，分解根本做不出来。反过来，$\boldsymbol{Q}=\boldsymbol{D}^{\top}\boldsymbol{D}$ 稠密而 $\boldsymbol{D}$ 稀疏时，直接用 $\boldsymbol{F}=\boldsymbol{D}$ 比存 $\boldsymbol{Q}$ 便宜。

改写的价值在于让问题能交给统一的求解方法，能和其他范数约束混用。只有二次目标和线性约束时，保留原形式通常更省。

20.3.2 Schur 补改写

二次上界和矩阵的逆都不是矩阵元素的线性函数。这一小节回答：这种限制能否写成线性矩阵不等式？工具是 Schur 补，关键是分清哪一块必须正定。

从配方到判据 先看 2×2 的情形。设 $p>0$，考虑二次型

$$pa^2+2nab+Tb^2.$$

配方得到

$$p\Big(a+\frac{n}{p}b\Big)^2+\Big(T-\frac{n^2}{p}\Big)b^2.$$

第一项可以用 a 消成零，所以整个二次型非负，取决于第二项的系数 $T-n^2/p$ 是否非负。

矩阵版本完全类似，只是把除以 p 换成乘以逆矩阵。

引理 20.23 Schur 补判据 设对称矩阵分块为

$$\boldsymbol{M}=\begin{bmatrix}\boldsymbol{P} & \boldsymbol{N}\\ \boldsymbol{N}^{\top} & \boldsymbol{T}\end{bmatrix}, \tag{20.35}$$

其中 $\boldsymbol{P}\succ\boldsymbol{0}$。则

$$\boldsymbol{M}\succeq\boldsymbol{0}\quad\Longleftrightarrow\quad\boldsymbol{T}-\boldsymbol{N}^{\top}\boldsymbol{P}^{-1}\boldsymbol{N}\succeq\boldsymbol{0}. \tag{20.36}$$

矩阵 $\boldsymbol{T}-\boldsymbol{N}^{\top}\boldsymbol{P}^{-1}\boldsymbol{N}$ 称为 $\boldsymbol{P}$ 在 $\boldsymbol{M}$ 中的Schur补（Schur complement）。

证明　对任意向量 $\boldsymbol{a},\boldsymbol{b}$，记 $\boldsymbol{S}=\boldsymbol{T}-\boldsymbol{N}^{\top}\boldsymbol{P}^{-1}\boldsymbol{N}$。配方得到

$$\begin{bmatrix}\boldsymbol{a}\\ \boldsymbol{b}\end{bmatrix}^{\top}\boldsymbol{M}\begin{bmatrix}\boldsymbol{a}\\ \boldsymbol{b}\end{bmatrix}=(\boldsymbol{a}+\boldsymbol{P}^{-1}\boldsymbol{N}\boldsymbol{b})^{\top}\boldsymbol{P}(\boldsymbol{a}+\boldsymbol{P}^{-1}\boldsymbol{N}\boldsymbol{b})+\boldsymbol{b}^{\top}\boldsymbol{S}\boldsymbol{b}.$$

若 $\boldsymbol{S}\succeq\boldsymbol{0}$，右端两项都非负，$\boldsymbol{M}\succeq\boldsymbol{0}$。

反过来，设 $\boldsymbol{M}\succeq\boldsymbol{0}$。对任意 $\boldsymbol{b}$，取 $\boldsymbol{a}=-\boldsymbol{P}^{-1}\boldsymbol{N}\boldsymbol{b}$，第一项变为零，于是 $\boldsymbol{b}^{\top}\boldsymbol{S}\boldsymbol{b}\geq 0$。 ■

式 (20.36)的左端对 $\boldsymbol{P},\boldsymbol{N},\boldsymbol{T}$ 是线性的，右端含有逆和乘积。这就是改写的用处：把弯曲的右端换成线性的左端。

二次型上界　令 $\boldsymbol{P}=\boldsymbol{I}$、$\boldsymbol{N}=\boldsymbol{u}$、$\boldsymbol{T}=t$，由引理 20.23，

$$\|\boldsymbol{u}\|_2^2\leq t\quad\Longleftrightarrow\quad\begin{bmatrix}\boldsymbol{I}&\boldsymbol{u}\\ \boldsymbol{u}^{\top}&t\end{bmatrix}\succeq\boldsymbol{0}.\tag{20.37}$$

代入 $\boldsymbol{u}=\boldsymbol{D}\boldsymbol{x}-\boldsymbol{r}$，左端对 $\boldsymbol{x}$ 是二次的，右端的矩阵对 $(\boldsymbol{x},t)$ 却是仿射的。这条约束就是一条线性矩阵不等式，和式 (20.25)同型。这里单位块 $\boldsymbol{I}$ 恒正定，引理的条件自动满足。

以预算问题的解为例，$\|\boldsymbol{u}\|_2^2=9/2$。取 $t=9/2$，矩阵是 4×4 的，它的 Schur 补为零，矩阵半正定且奇异。取 t 更小，Schur 补为负，矩阵不再半正定。

含逆矩阵的限制　再看一个 $\boldsymbol{P}$ 本身是变量的例子。设 $\boldsymbol{Y}\succ\boldsymbol{0}$ 是对称矩阵变量，$\boldsymbol{b}$ 是向量，由引理 20.23，

$$\boldsymbol{b}^{\top}\boldsymbol{Y}^{-1}\boldsymbol{b}\leq t\quad\Longleftrightarrow\quad\begin{bmatrix}\boldsymbol{Y}&\boldsymbol{b}\\ \boldsymbol{b}^{\top}&t\end{bmatrix}\succeq\boldsymbol{0}\qquad(\boldsymbol{Y}\succ\boldsymbol{0}).\tag{20.38}$$

右端是 $(\boldsymbol{Y},\boldsymbol{b},t)$ 的线性矩阵不等式，也说明左端的函数在 $\boldsymbol{Y}\succ\boldsymbol{0}$ 上对 $(\boldsymbol{Y},\boldsymbol{b})$ 联合凸：它的上图由一条线性矩阵不等式定义。

用数值走一遍。取

$$\boldsymbol{Y}=\begin{bmatrix}2&1\\ 1&2\end{bmatrix},\qquad\boldsymbol{b}=\begin{bmatrix}1\\ 1\end{bmatrix}.$$

矩阵的逆是

$$\boldsymbol{Y}^{-1}=\frac{1}{3}\begin{bmatrix}2&-1\\ -1&2\end{bmatrix}.$$

代入得到

$$\boldsymbol{b}^{\top}\boldsymbol{Y}^{-1}\boldsymbol{b} = \frac{1}{3}(2-1-1+2) = \frac{2}{3}.$$

3×3 块矩阵的行列式等于 $\det \boldsymbol{Y}$ 与 Schur 补的乘积，

$$\det \boldsymbol{M} = 3\Big(t - \frac{2}{3}\Big).$$

于是 $t < 2/3$ 时矩阵不半正定，$t = 2/3$ 时恰好在边界上。数值上，$t = 1/2$ 时最小特征值约为 -0.137，$t = 1$ 时约为 0.268。图 20.17(a) 画出最小特征值穿过零点的过程。

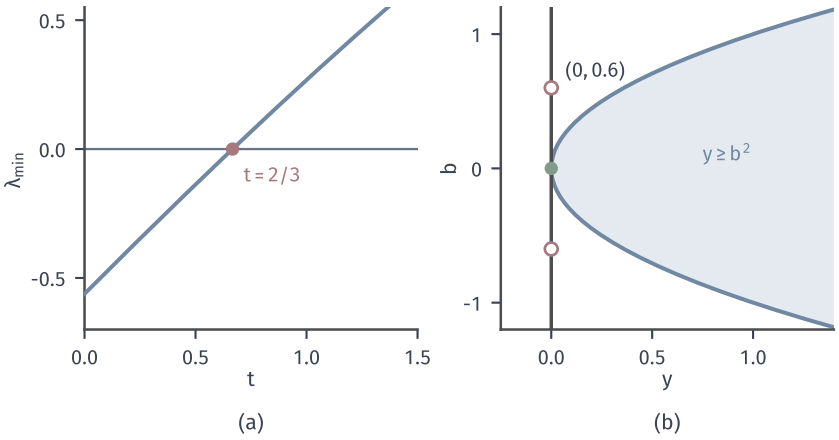


图 20.17　Schur 补判据及其边界。(a) 式 (20.38)的块矩阵的最小特征值随 t 的变化，红点是 $t = 2/3$。(b) $\begin{bmatrix} y & b \\ b & 1 \end{bmatrix} \succeq \mathbf{0}$ 的解集（浅蓝）是抛物线 $y \geq b^2$ 的内部及边界。深灰线 $y = 0$ 上只有绿点 $(0,0)$ 可行，红色空心点 $(0, \pm 0.6)$ 不可行。

奇异的情形　$\boldsymbol{P}$ 只半正定时，不能写 $\boldsymbol{P}^{-1}$，把逆换成伪逆也不够。看一个例子：

$$\begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix}.$$

这里 $\boldsymbol{P} = 0$，伪逆也是 0，“Schur 补”算出来是 $1 \geq 0$。但矩阵的行列式是 -1，它不半正定。缺的是一个像空间的条件：$\boldsymbol{P}$ 的零方向上，$\boldsymbol{N}$ 也必须为零。

引理 20.24　奇异情形的 Schur 补判据　在引理 20.23的分块中，设 $\boldsymbol{P} \succeq \mathbf{0}$，$\boldsymbol{P}^{\dagger}$ 是其伪逆。则 $\boldsymbol{M} \succeq \mathbf{0}$，当且仅当

$$(\boldsymbol{I} - \boldsymbol{P}\boldsymbol{P}^{\dagger})\boldsymbol{N} = \mathbf{0} \quad \text{且} \quad \boldsymbol{T} - \boldsymbol{N}^{\top}\boldsymbol{P}^{\dagger}\boldsymbol{N} \succeq \mathbf{0}. \tag{20.39}$$

证明　设 $\boldsymbol{M} \succeq \boldsymbol{0}$。任取 $\boldsymbol{w} \in \ker \boldsymbol{P}$ 和向量 $\boldsymbol{v}$，把 $\boldsymbol{M}$ 的二次型作用在 $(\boldsymbol{w}, \varepsilon \boldsymbol{v})$ 上，得到

$$2\varepsilon \boldsymbol{w}^{\top} \boldsymbol{N} \boldsymbol{v} + \varepsilon^{2} \boldsymbol{v}^{\top} \boldsymbol{T} \boldsymbol{v} \geq 0.$$

这对正负的小 ε 都成立，必有 $\boldsymbol{w}^{\top} \boldsymbol{N} \boldsymbol{v} = 0$。所以 $\boldsymbol{N}$ 的列与 $\ker \boldsymbol{P}$ 正交，属于 $\operatorname{range} \boldsymbol{P}$，这正是 $\boldsymbol{P}\boldsymbol{P}^{\dagger}\boldsymbol{N} = \boldsymbol{N}$。

在条件 $\boldsymbol{P}\boldsymbol{P}^{\dagger}\boldsymbol{N} = \boldsymbol{N}$ 之下，令

$$\boldsymbol{U} = \begin{bmatrix} \boldsymbol{I} & -\boldsymbol{P}^{\dagger}\boldsymbol{N} \\ \boldsymbol{0} & \boldsymbol{I} \end{bmatrix},$$

它可逆。直接相乘，并用 $\boldsymbol{P}^{\dagger}\boldsymbol{P}\boldsymbol{P}^{\dagger} = \boldsymbol{P}^{\dagger}$，得到

$$\boldsymbol{U}^{\top} \boldsymbol{M} \boldsymbol{U} = \begin{bmatrix} \boldsymbol{P} & \boldsymbol{0} \\ \boldsymbol{0} & \boldsymbol{T} - \boldsymbol{N}^{\top}\boldsymbol{P}^{\dagger}\boldsymbol{N} \end{bmatrix}.$$

可逆合同变换保持半正定性，所以 $\boldsymbol{M} \succeq \boldsymbol{0}$ 当且仅当右端半正定，也就是第二个条件成立。这同时完成了两个方向的证明。 ■

图 20.17(b) 展示了这个条件的几何含义。$\begin{bmatrix} y & b \\ b & 1 \end{bmatrix} \succeq \boldsymbol{0}$ 在 $y > 0$ 时等价于 $b^{2}/y \leq 1$，即 $y \geq b^{2}$。到 $y = 0$ 时，b^{2}/y 没有定义，判据要求 $b = 0$，图中只有原点留下。

这里还有一个定义域的问题。式 (20.38)要求 $\boldsymbol{Y} \succ \boldsymbol{0}$，而块矩阵半正定只推出 $\boldsymbol{Y} \succeq \boldsymbol{0}$。改写时若丢掉严格正定的要求，集合就多了边界上的奇异 $\boldsymbol{Y}$，这些点在原问题中 $\boldsymbol{Y}^{-1}$ 并无定义。这时要么说明原函数在边界上取什么值，要么在求解后核对 $\boldsymbol{Y}$ 是否真的正定。

二阶锥也是线性矩阵不等式　同样的工具给出

$$\|\boldsymbol{u}\|_{2} \leq t \quad \Longleftrightarrow \quad \begin{bmatrix} t\boldsymbol{I} & \boldsymbol{u} \\ \boldsymbol{u}^{\top} & t \end{bmatrix} \succeq \boldsymbol{0}. \tag{20.40}$$

$t > 0$ 时由引理 20.23，Schur 补是 $t - \boldsymbol{u}^{\top}\boldsymbol{u}/t$。$t = 0$ 时左上块为零，由引理 20.24迫使 $\boldsymbol{u} = \boldsymbol{0}$。$t < 0$ 时对角元为负，矩阵不半正定。三种情形都与左式一致。

所以二阶锥规划可以写成半正定规划。这种包含关系的计算含义留到第 20.5节讨论。

20.4 半正定松弛

20.1 二次规划
20.2 锥规划
20.3 等价改写
20.4 半正定松弛
20.4.1 松弛下界
20.4.2 原解恢复
20.4.3 上下界检验
20.5 模型与求解方法
20.6 本章小结

第 20.1.3小节的问题不能等价地改写成凸问题，KKT 条件也给不出全局证书。既然改不成凸问题，能否算出一个有保证的下界，用它判断手上的候选解离最优还有多远？

把乘积收集到矩阵里 考虑二次约束二次规划（quadratically constrained quadratic program，QCQP）

$$\begin{aligned} \min_{\boldsymbol{x}\in\mathbb{R}^n} \quad & \boldsymbol{x}^\top \boldsymbol{Q}_0 \boldsymbol{x} + 2\boldsymbol{q}_0^\top \boldsymbol{x} + c_0 \\ \text{s.t.} \quad & \boldsymbol{x}^\top \boldsymbol{Q}_i \boldsymbol{x} + 2\boldsymbol{q}_i^\top \boldsymbol{x} + c_i \le 0, \quad i = 1, \dots, m, \end{aligned} \tag{20.41}$$

其中 $\boldsymbol{Q}_i$ 对称，可以不定。等式约束可以拆成两条不等式，因此这里只写不等式。

难点全在乘积 $x_i x_j$ 上。这些乘积在 $\boldsymbol{x}$ 上是非线性的，但只要把它们看成新的未知数，每个二次式都变成新未知数的线性函数。这就像把一笔难算的账换一种记法：先不管各项之间的关系，只把用到的项登记下来，账立刻变成加法。这个类比的边界是：各项之间的关系并没有消失，它们藏在下面矩阵的结构里，后面要单独处理。

具体做法是引入带常数坐标的矩阵

$$\boldsymbol{Y} = \begin{bmatrix} 1 \\ \boldsymbol{x} \end{bmatrix} \begin{bmatrix} 1 \\ \boldsymbol{x} \end{bmatrix}^\top = \begin{bmatrix} 1 & \boldsymbol{x}^\top \\ \boldsymbol{x} & \boldsymbol{x}\boldsymbol{x}^\top \end{bmatrix} \in \mathcal{S}^{n+1}, \tag{20.42}$$

行列下标从 0 开始。常数坐标的作用是把线性项和常数项也放进矩阵。记

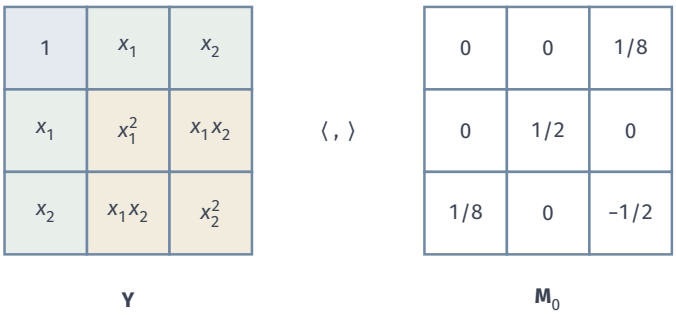
$$\boldsymbol{M}_i = \begin{bmatrix} c_i & \boldsymbol{q}_i^\top \\ \boldsymbol{q}_i & \boldsymbol{Q}_i \end{bmatrix},$$

直接展开迹内积，得到

$$\boldsymbol{x}^\top \boldsymbol{Q}_i \boldsymbol{x} + 2\boldsymbol{q}_i^\top \boldsymbol{x} + c_i = \langle \boldsymbol{M}_i, \boldsymbol{Y} \rangle. \tag{20.43}$$

原来的二次式成了 $\boldsymbol{Y}$ 的线性函数。

图 20.18以式 (20.13)为例。这时 $\boldsymbol{Q}_0 = \operatorname{diag}(1/2, -1/2)$，$\boldsymbol{q}_0 = (0, 1/8)$，$c_0 = 0$。



20.1 二次规划
20.2 锥规划
20.3 等价改写
20.4 半正定松弛
20.4.1 松弛下界
20.4.2 原解恢复
20.4.3 上下界检验
20.5 模型与求解方法
20.6 本章小结

图 20.18 提升矩阵与目标系数。左边是 $n=2$ 时的 $\boldsymbol{Y}$，浅蓝格是常数，绿格是一次项，黄格是二次项。右边是目标 $\frac{1}{2}x_1^2-\frac{1}{2}x_2^2+\frac{1}{4}x_2$ 对应的 $\boldsymbol{M}_0$，交叉项的系数对半分在两个对称位置上。二者的迹内积就是目标。

哪些矩阵来自向量 不是每个矩阵都有式 (20.42)的形状。下面的引理精确地指出需要哪些条件。

引理 20.25 秩一刻画 $\boldsymbol{Y}\in\mathcal{S}^{n+1}$ 具有式 (20.42)的形状，当且仅当

$$\boldsymbol{Y}\succeq\boldsymbol{0},\qquad Y_{0,0}=1,\qquad \operatorname{rank}\boldsymbol{Y}=1. \tag{20.44}$$

证明 式 (20.42)的矩阵满足这三条：它是一个向量与自身的外积，秩为一且半正定，第一个元素是 1。反过来，秩一半正定矩阵可以写成 $\boldsymbol{Y}=\boldsymbol{v}\boldsymbol{v}^{\mathsf{T}}$。由 $Y_{0,0}=v_0^2=1$ 得 $v_0=\pm1$，必要时把 $\boldsymbol{v}$ 换成 $-\boldsymbol{v}$，可设 $v_0=1$。记 $\boldsymbol{v}=(1,\boldsymbol{x})$，$\boldsymbol{Y}$ 就有所要的形状。 ■

于是问题 (20.41)等价于在条件 (20.44)和 $\langle\boldsymbol{M}_i,\boldsymbol{Y}\rangle\le0$ 下最小化 $\langle\boldsymbol{M}_0,\boldsymbol{Y}\rangle$。目标和约束都是线性的，半正定和 $Y_{0,0}=1$ 也是凸约束，全部困难集中在秩一这一条上。

把它删掉，就得到**半正定松弛**（semidefinite relaxation）

$$\begin{aligned}\min_{\boldsymbol{Y}\in\mathcal{S}^{n+1}}\quad & \langle\boldsymbol{M}_0,\boldsymbol{Y}\rangle\\ \text{s.t.}\quad & \langle\boldsymbol{M}_i,\boldsymbol{Y}\rangle\le0,\quad i=1,\dots,m,\\ & Y_{0,0}=1,\quad \boldsymbol{Y}\succeq\boldsymbol{0}.\end{aligned} \tag{20.45}$$

20.4.1 松弛下界

删掉一个约束，最优值只会变小。这一小节要把这件事写准确，并弄清楚上面的几步各自改变了什么。

定理 20.26 松弛给出下界 记问题 (20.41)的最优值为 $f^\star$，问题 (20.45)的最优值为 p_{rel}。则

$$p_{\mathrm{rel}} \le f^\star. \tag{20.46}$$

证明 任取问题 (20.41)的可行点 $\boldsymbol{x}$，按式 (20.42)构造 $\boldsymbol{Y}$。由引理 20.25，$\boldsymbol{Y} \succeq \boldsymbol{0}$ 且 $Y_{0,0} = 1$。由式 (20.43)，$\langle \boldsymbol{M}_i, \boldsymbol{Y} \rangle \le 0$，且 $\langle \boldsymbol{M}_0, \boldsymbol{Y} \rangle$ 等于原目标值。所以 $\boldsymbol{Y}$ 对问题 (20.45)可行，p_{rel} 不超过原目标值。对所有可行 $\boldsymbol{x}$ 取下确界，即得结论。 ■

这个结论只用到定义 20.19的第一条。第二条在这里不成立，因为松弛问题的可行矩阵不一定对应任何 $\boldsymbol{x}$。表 20.7把三步分开。

步骤	做了什么	与原问题的关系
提升	用 $\boldsymbol{Y}$ 表示乘积，保留秩一	等价
放松秩约束	删去 $\operatorname{rank} \boldsymbol{Y} = 1$	可行集变大，得到下界
求解松弛	数值计算 SDP	近似解，下界需验证

表 20.7 半正定松弛的三个步骤。只有第一步不改变问题。

示例 20.27 松弛证明全局最优 回到目标 (20.13)。可行集 $-1 \le x_2 \le 1$ 写成二次约束 $x_2^2 \le 1$。记 $\boldsymbol{Y}$ 的元素

$$\boldsymbol{Y} = \begin{bmatrix} 1 & y_1 & y_2 \\ y_1 & X_{1,1} & X_{1,2} \\ y_2 & X_{1,2} & X_{2,2} \end{bmatrix}.$$

松弛问题是在 $X_{2,2} \le 1$、$\boldsymbol{Y} \succeq \boldsymbol{0}$ 下最小化

$$\frac{1}{2} X_{1,1} - \frac{1}{2} X_{2,2} + \frac{1}{4} y_2.$$

下面逐项估计目标。半正定矩阵的对角元非负，所以 $X_{1,1} \ge 0$。约束给出 $X_{2,2} \le 1$。再由 $\{0,2\}$ 行列对应的 2×2 主子式非负，$y_2^2 \le X_{2,2} \le 1$，所以 $y_2 \ge -1$。三项合起来，

$$\frac{1}{2} X_{1,1} - \frac{1}{2} X_{2,2} + \frac{1}{4} y_2 \ge 0 - \frac{1}{2} - \frac{1}{4} = -\frac{3}{4}.$$

这个下界由点 A 对应的秩一矩阵取到，所以 $p_{\mathrm{rel}} = -3/4$，也就是 $f^\star = -3/4$。KKT 条件区分不开 A 和 B，松弛却直接证明了 A 是全局最优，而 B 的目标值 $-1/4$ 高于下界，不是全局最优。

符号变量　下面这个问题里，松弛一般不紧。设 $\boldsymbol{W} \in \mathcal{S}^n$，考虑

$$\min_{\boldsymbol{x}} \ \boldsymbol{x}^\top \boldsymbol{W} \boldsymbol{x} \quad \text{s.t.} \quad x_i^2 = 1, \quad i = 1, \dots, n. \tag{20.47}$$

变量只能取 ± 1，这是一个把点分到两侧的组合问题。约束 $x_i^2 = 1$ 恰好是二次的，提升后成为对角线上的线性条件，一条也不丢。

这里没有线性项，$\boldsymbol{Y}$ 中的 $\boldsymbol{x}$ 块可以去掉。设 $\boldsymbol{Y}$ 可行，记其 $\boldsymbol{x}$ 块为 $\hat{\boldsymbol{x}}$，令 $\boldsymbol{D}_\pm = \operatorname{diag}(1, -\boldsymbol{I})$。矩阵 $\boldsymbol{D}_\pm \boldsymbol{Y} \boldsymbol{D}_\pm$ 也可行，目标不变，只是 $\hat{\boldsymbol{x}}$ 变号。二者的平均仍可行，而 $\boldsymbol{x}$ 块为零。所以只需保留右下块 $\boldsymbol{X} = \boldsymbol{x}\boldsymbol{x}^\top$，松弛写成

$$\min_{\boldsymbol{X} \in \mathcal{S}^n} \langle \boldsymbol{W}, \boldsymbol{X} \rangle \quad \text{s.t.} \quad X_{i,i} = 1, \quad i = 1, \dots, n, \quad \boldsymbol{X} \succeq \boldsymbol{0}. \tag{20.48}$$

取 $\boldsymbol{A}_i = \boldsymbol{e}_i \boldsymbol{e}_i^\top$、$b_i = 1$，由式 (20.29)，它的对偶问题是

$$\max_{\boldsymbol{y} \in \mathbb{R}^n} \sum_{i=1}^{n} y_i \quad \text{s.t.} \quad \boldsymbol{W} - \operatorname{diag}(\boldsymbol{y}) \succeq \boldsymbol{0}. \tag{20.49}$$

先看 $n = 2, \boldsymbol{W}$ 的对角元为零、非对角元为 1。松弛的可行矩阵是 $\begin{bmatrix} 1 & a \\ a & 1 \end{bmatrix}$，$a \in [-1, 1]$，目标是 $2a$。最优在 $a = -1$ 取到，矩阵秩一，对应 $\boldsymbol{x} = (1, -1)$，松弛是紧的。

再看三角形的例子。取 $n = 3$，

$$\boldsymbol{W} = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}.$$

目标是 $2(x_1 x_2 + x_1 x_3 + x_2 x_3)$。枚举 8 个符号组合，全同时目标为 6，其余都是两个相同、一个相反，目标为 -2。所以 $f^\star = -2$。

松弛问题中取

$$\hat{\boldsymbol{X}} = \begin{bmatrix} 1 & -1/2 & -1/2 \\ -1/2 & 1 & -1/2 \\ -1/2 & -1/2 & 1 \end{bmatrix}.$$

它的特征值是 $0, 3/2, 3/2$，半正定，对角元都是 1，所以松弛可行。六个非对角元各贡献 $-1/2$，目标是

$$\langle \boldsymbol{W}, \hat{\boldsymbol{X}} \rangle = -3.$$

再看对偶问题 (20.49)。取 $\boldsymbol{y} = (-1, -1, -1)$，则

$$\boldsymbol{W} - \operatorname{diag}(\boldsymbol{y}) = \boldsymbol{W} + \boldsymbol{I} = \boldsymbol{1}\boldsymbol{1}^\top \succeq \boldsymbol{0},$$

20.1 二次规划
20.2 锥规划
20.3 等价改写
20.4 半正定松弛
20.4.1 松弛下界
20.4.2 原解恢复
20.4.3 上下界检验
20.5 模型与求解方法
20.6 本章小结

对偶目标是 -3。原始和对偶的值相等，所以 $p_{\text{rel}} = -3$。

下界 -3 比真实最优值 -2 低了 1，这个间隙来自放松秩约束，而不是求解误差。图 20.19在切片上画出了可行集究竟扩大了多少。

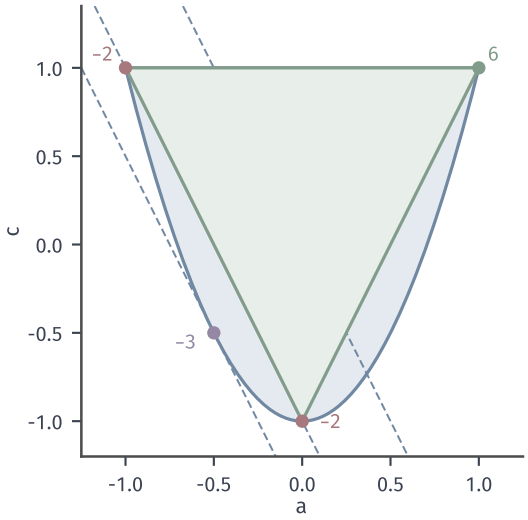


图 20.19 $n = 3$ 时松弛可行集在切片 $X_{1,2} = X_{1,3} = a$、$X_{2,3} = c$ 上的形状。浅蓝抛物线区域 $2a^2 - 1 \le c \le 1$ 是松弛的可行集。绿色三角形是秩一矩阵（符号解）的凸包，其顶点旁标注目标 $4a + 2c$ 的值。蓝色虚线是等值线，紫点是松弛最优解，目标 -3，它在三角形之外。

切片的形状可以直接算出来。矩阵 $\begin{bmatrix} 1 & a & a \\ a & 1 & c \\ a & c & 1 \end{bmatrix}$ 有特征向量 $(0, 1, -1)$，特征值 $1-c$，要求 $c \le 1$。在与之正交的子空间上，矩阵约化为 $\begin{bmatrix} 1 & \sqrt{2}a \\ \sqrt{2}a & 1+c \end{bmatrix}$，半正定要求 $1 + c \ge 2a^2$。

20.4.2 原解恢复

松弛的解是矩阵，原问题要的是向量。这一小节回答：什么时候可以把向量直接读出来，读不出来时又该怎么办？

秩一的情形 若松弛的最优矩阵恰好秩一，问题就结束了。

定理 20.28 秩一解恢复原问题的最优解 设 $\boldsymbol{Y}^\star$ 是问题 (20.45)的最优解，且 $\operatorname{rank} \boldsymbol{Y}^\star = 1$。取 $\boldsymbol{x}^\star$ 为 $\boldsymbol{Y}^\star$ 第 0 列的后 n 个元素。则 $\boldsymbol{x}^\star$ 是问题 (20.41)的全局最优解，且 $p_{\text{rel}} = f^\star$。

证明 由引理 20.25，$\boldsymbol{Y}^\star$ 具有式 (20.42)的形状，其中的向量就是 $\boldsymbol{x}^\star$。由式 (20.43)，$\boldsymbol{x}^\star$ 满足全部约束，目标值等于 p_{rel}。结合式 (20.46)，

$$f(\boldsymbol{x}^\star) = p_{\text{rel}} \le f^\star \le f(\boldsymbol{x}^\star).$$

所以三者相等。 ■

定理依赖于约束的对应关系：松弛必须把原问题的每条约束都按式 (20.43)写了进去。若为了省事删掉了某条约束，恢复的 $\boldsymbol{x}^\star$ 还要单独检查这条约束。

高秩的情形 矩阵的秩大于 1 时，它不是任何向量的外积，松弛的最优矩阵不是原问题的可行解。这时要把矩阵“变回”向量，常用两种办法：取最大特征值对应的特征向量作投影；或者把矩阵分解后随机取整。无论哪一种，都是问题专属的启发式步骤。

对符号问题，常用的取整步骤如下[3]。把 $\boldsymbol{X}$ 分解成 $X_{i,j} = \boldsymbol{v}_i^{\mathsf{T}} \boldsymbol{v}_j$，$\boldsymbol{v}_i$ 是单位向量，因为对角元是 1。随机抽取一个标准高斯向量 $\boldsymbol{g}$，令

$$x_i = \operatorname{sign}(\boldsymbol{v}_i^{\mathsf{T}} \boldsymbol{g}). \tag{20.50}$$

几何上，这是用一个随机的超平面把各个单位向量分成两侧，同侧的 x_i 相同。

两个向量被分开的概率与它们的夹角成正比。$\boldsymbol{g}$ 在 $\boldsymbol{v}_i, \boldsymbol{v}_j$ 所在平面上的投影方向是均匀的，夹角为 θ 时被分开的概率是 θ/π。于是

$$\mathbb{E}[x_i x_j] = 1 - \frac{2\theta}{\pi} = \frac{2}{\pi} \arcsin X_{i,j}. \tag{20.51}$$

最后一步用了 $\theta = \arccos X_{i,j}$ 和 $\arcsin z = \pi/2 - \arccos z$。

三角形的 $\hat{\boldsymbol{X}}$ 可以分解成平面上三个互成 120° 的单位向量，见图 20.20(a)。任何一条过原点的直线都把三个向量分成一个和两个。所以取整结果总是两同一异，目标总是 -2，碰巧等于 $f^\star$。由式 (20.51)验证，$\mathbb{E}[x_i x_j] = -1/3$，目标的期望是 $6 \cdot (-1/3) = -2$。

[3] M. X. Goemans, D. P. Williamson, *Improved Approximation Algorithms for Maximum Cut and Satisfiability Problems Using Semidefinite Programming* In Journal of the ACM, 1995, vol. 42, no. 6, pp. 1115–1145

20.1 二次规划
20.2 锥规划
20.3 等价改写
20.4 半正定松弛
20.4.1 松弛下界
20.4.2 原解恢复
20.4.3 上下界检验
20.5 模型与求解方法
20.6 本章小结

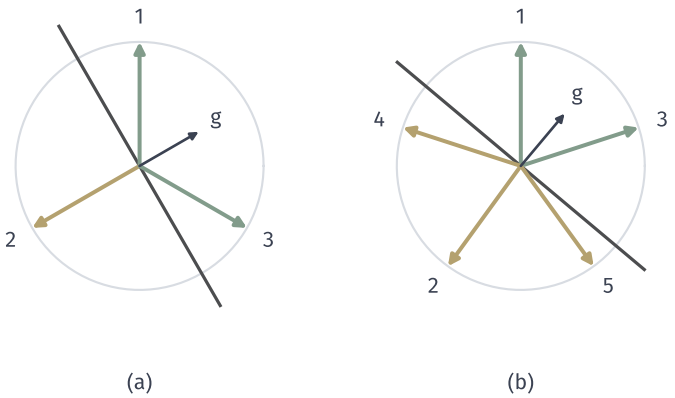


图 20.20 随机超平面取整。深灰线是与随机方向 $\boldsymbol{g}$ 垂直的直线，绿色向量对应 $x_i = 1$，黄色向量对应 $x_i = -1$。(a) 三角形问题的三个向量互成 120°。(b) 五边形问题的五个向量，相邻编号之间夹角 144°。

恢复可能破坏可行性 取整会改变目标，也会破坏约束。设问题 (20.47)中 $n = 4$,再加上平衡约束 $x_1+x_2+x_3+x_4 = 0$。把它平方后提升为 $\langle \mathbf{1}\mathbf{1}^{\top}, \boldsymbol{X}\rangle = 0$。矩阵

$$\boldsymbol{X} = \frac{4}{3}\boldsymbol{I} - \frac{1}{3}\mathbf{1}\mathbf{1}^{\top}$$

对角元为 1，非对角元为 $-1/3$，特征值是 $4/3, 4/3, 4/3, 0$，且 $\langle \mathbf{1}\mathbf{1}^{\top}, \boldsymbol{X}\rangle = 4 - 12/3 = 0$，满足松弛的全部约束。

它对应四面体的四个顶点方向，这四个向量和为零，一个超平面不可能把它们全放在同一侧，取整结果只有两种：二比二（满足平衡约束）或一比三（$(\sum_i x_i)^2 = 4$，违反约束）。由式 (20.51)，

$$\mathbb{E}\Big[\big(\sum_i x_i\big)^2\Big] = 4 + 12 \cdot \frac{2}{\pi}\arcsin\Big(-\frac{1}{3}\Big) \approx 1.404.$$

除以 4，一比三的概率约为 0.351。超过三分之一的取整结果是不可行的，必须修复或丢弃后重新检验。

20.4.3 上下界检验

松弛算出来的数字到底保证了什么？这一小节把上界、下界和间隙分别交代清楚。

两个界 一个经过原约束核对的点 $\hat{\boldsymbol{x}}$ 给出上界 $U = f(\hat{\boldsymbol{x}})$。一个松弛的对偶可行解 $\boldsymbol{y}$ 给出下界 L，对符号问题就是 $L = \sum_i y_i$。合起来是一条链：

$$L \le p_{\mathrm{rel}} \le f^{\star} \le U. \tag{20.52}$$

报告时写出 $U - L$。它同时包含松弛自身的间隙和求解的误差，是对 $\hat{\boldsymbol{x}}$ 质量的一个可靠估计。

在三角形例子中，$U = -2$，$L = -3$，$U - L = 1$。这里 $\hat{\boldsymbol{x}}$ 其实已经最优，间隙全部来自松弛，继续迭代也不会缩小。间隙不为零，不代表候选解不好。

近似原始值不是下界 常见的错误是把松弛问题的一个可行矩阵的目标值当作下界。式 (20.52)中排在 $f^\star$ 左边的是 p_{rel}，而可行矩阵 $\hat{\boldsymbol{X}}$ 的目标值满足的是

$$\langle \boldsymbol{W}, \hat{\boldsymbol{X}} \rangle \geq p_{\mathrm{rel}},$$

方向相反。它可以高于 $f^\star$。

取三角形问题中对角元为 1、非对角元为 -0.3 的矩阵，特征值是 $0.4, 1.3, 1.3$，松弛可行，目标是 -1.8。可 $f^\star = -2 < -1.8$。若把 -1.8 当作下界，就会错误地断言符号问题的最优值不低于 -1.8，如图 20.21所示。

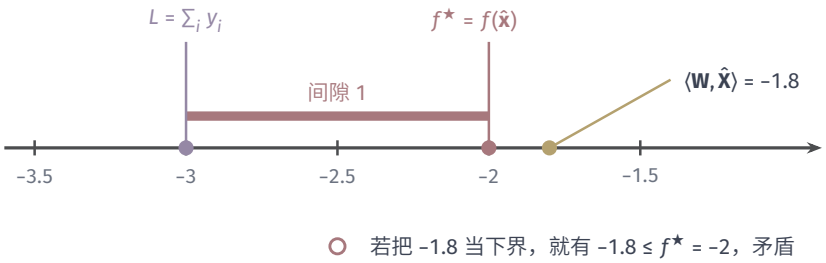


图 20.21 三角形符号问题的各个数值。紫点是对偶可行解给出的下界 $L = -3$，红点是最优值 $f^\star = -2$，它也等于取整解的上界。黄点是松弛的一个未收敛可行矩阵的目标值 -1.8，位于 $f^\star$ 右侧，不能当作下界。红色粗线是报告的间隙。

从近似对偶解得到有效下界 数值求解器返回的 $\boldsymbol{y}$ 往往只是近似可行，$\boldsymbol{W} - \mathrm{diag}(\boldsymbol{y})$ 可能有微小的负特征值，严格说来式 (20.52)不能用。幸好符号问题的对偶可行性很容易修复。

引理 20.29 修复对偶可行性 对任意 $\boldsymbol{y} \in \mathbb{R}^n$，记 λ 为矩阵 $\boldsymbol{W} - \mathrm{diag}(\boldsymbol{y})$ 的最小特征值。则

$$L(\boldsymbol{y}) = \sum_{i=1}^{n} y_i + n\lambda \tag{20.53}$$

是问题 (20.48)的最优值的下界，因而也是 $f^\star$ 的下界。

证明 令 $\boldsymbol{y}' = \boldsymbol{y} + \lambda \mathbf{1}$。则

$$\boldsymbol{W} - \operatorname{diag}(\boldsymbol{y}') = \boldsymbol{W} - \operatorname{diag}(\boldsymbol{y}) - \lambda \boldsymbol{I} \succeq \mathbf{0},$$

因为最小特征值被平移到了零。所以 $\boldsymbol{y}'$ 是问题 (20.49)的可行解，目标是 $\sum_i y_i + n\lambda$。由弱对偶和定理 20.26得到结论。 ■

这个界对任何 $\boldsymbol{y}$ 都成立，只要算得出最小特征值。例如在三角形问题中取不可行的 $\boldsymbol{y} = (-1.1, -0.9, -1)$，最小特征值约为 -0.059，修复后 $L \approx -3.177$，仍是有效的下界。数值计算特征值本身有误差，严格的报告还要再减去一个反映舍入误差的小量。

图 20.22是一个 10 个变量的符号问题，权重是固定种子生成的 ± 1。枚举全部符号组合得到 $f^\star = -46$。求解松弛时，绿线是原始可行矩阵的目标值，紫线是由式 (20.53)修复的下界。

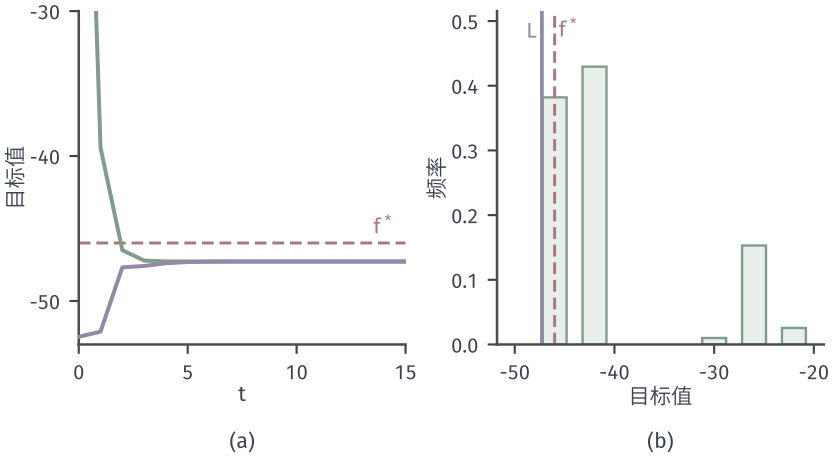


图 20.22 $n = 10$ 的符号问题（$\boldsymbol{W}$ 的非对角元为随机 ± 1，种子 7）。(a) 松弛的求解过程：绿线是可行矩阵的目标值，紫线是修复后的对偶下界，红色虚线是枚举得到的 $f^\star = -46$。前两步绿线高于 $f^\star$，不是 $f^\star$ 的下界；收敛后二者相遇在 $L \approx -47.28$。(b) 从最终矩阵取整 2000 次得到的目标值分布，紫线是 L，红色虚线是 $f^\star$。

绿线在开始两步高于 $f^\star$，把它当下界会得到错误的结论。收敛后两条线都停在 -47.28 附近，这就是 p_{rel}，它比 $f^\star$ 低约 1.28。这段距离是放松秩约束的代价，再多的迭代也消除不了。

图的 (b) 部分取整 2000 次。约 38% 的试验得到 -46，也就是真实最优值；其余的目标更差，最差到 -22。所以取整要重复多次，取其中最好的可行点作为上界。这里 $U = -46$，$U - L \approx 1.28$，已经足以说明候选解很接近最优。

20.1 二次规划
20.2 锥规划
20.3 等价改写
20.4 半正定松弛
20.5 模型与求解方法
20.6 本章小结

表 20.8整理了各个量的含义和要做的核对。

量	保证	需要核对
$f(\hat{\boldsymbol{x}})$	$f^\star$ 的上界	$\hat{\boldsymbol{x}}$ 满足原约束
$\sum_i y_i$	$f^\star$ 的下界	$\boldsymbol{y}$ 对偶可行
$\langle \boldsymbol{W}, \hat{\boldsymbol{X}} \rangle$	收敛时接近 p_{rel}	不是 $f^\star$ 的界
$U - L$	候选解的最优性间隙	上下两界都已核对

表 20.8　半正定松弛的结果中各个量的含义。

20.5 模型与求解方法

同一个问题可以有多种写法。于是要问：写法不同时，变量规模、存储和运算量分别差多少，应该按什么选择？

同一个问题的三种写法　预算问题已经写过三遍：原变量的二次规划、式 (20.34)的二阶锥形式，以及用式 (20.37)得到的线性矩阵不等式。三者等价，解都是 $(3/2, 1/2)$，规模却不同。表 20.9列出例子（$n = 2$，$k = 3$）和一般情形。

	二次规划	二阶锥形式	线性矩阵不等式
变量	2（一般 n）	3（$n + 1$）	3（$n + 1$）
非线性结构	$\boldsymbol{Q}$，2×2	5 维锥（$k + 2$）	4×4（$k + 1$ 阶）
矩阵独立元素	3	无	10
恢复原变量	直接	丢弃 t	丢弃 t

表 20.9　预算问题的三种等价写法。括号内是一般规模：n 个变量，$\boldsymbol{F} \in \mathbb{R}^{k \times n}$。线性约束三者相同，未列出。

模型的包含关系　图 20.23把前面的改写连成一条链。线性规划是 $\boldsymbol{Q} = \boldsymbol{0}$ 的二次规划；凸二次规划由式 (20.34)写成二阶锥规划；二阶锥规划由式 (20.40)写成半正定规划。

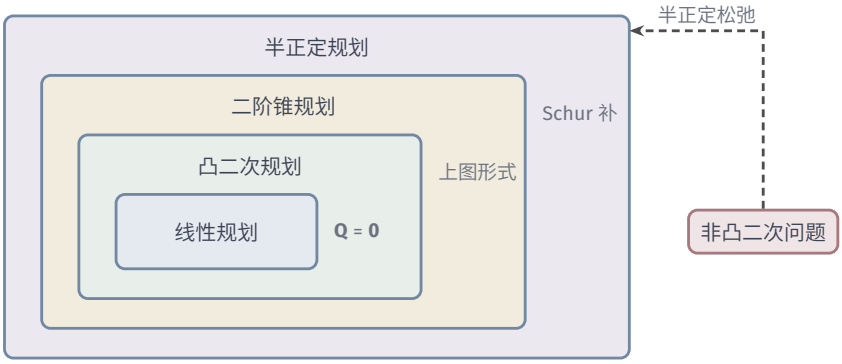


图 20.23 模型的包含关系。边框旁标注内层写成外层所用的改写。非凸二次问题不在这条链上，它只能经半正定松弛（虚线）得到下界。

这条链说的是表达能力，不是推荐的求解路线。外层的模型能表达内层的问题，但内层的结构在外层看不见了。一个 $k+2$ 维的二阶锥写成线性矩阵不等式后，要用 $(k+1)\times(k+1)$ 的矩阵，存储从 $O(k)$ 变成 $O(k^2)$。

内点法每步解一个线性方程，按稠密数据粗略估计：n 个变量的二次规划，每步约 $O(n^3)$ 次运算；变量为 n、矩阵阶为 k 的线性矩阵不等式，组装牛顿方程的系数矩阵就要 $O(nk^3+n^2k^2)$ 次，分解再要 $O(n^3)$ 次[4]。所以能用内层模型时就不要往外走。

[4] S. Boyd, L. Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004

松弛的规模 半正定松弛的规模增长更快。问题 (20.48)把 n 个变量换成 $n\times n$ 的矩阵。$n=1000$ 时，矩阵存储 10^6 个数，独立的非对角元有 $n(n-1)/2=499500$ 个，一次特征分解约 10^9 次运算。此外还要重复取整和验证。松弛的结果换来的是一个下界，这个下界是否值得这样的代价，要看问题规模和对全局证据的需要。

各类方法的去向 后面几章给出具体的算法，这里只说明各自处理什么情形。第 23章把二次规划当作子问题反复求解。第 24章把第 4章的内点法推广到一般光滑约束和锥约束。

若可行集的投影便宜，或约束可以拆成几块分别处理，第 21章和第 22章的方法每步代价低得多，适合只需中等精度的大规模问题。

投影到半正定锥就是一个例子：作谱分解，把负特征值截成零。例如 $\begin{bmatrix}1&2\\2&1\end{bmatrix}$ 的特征值是 3 和 -1，特征向量是 $(1,1)/\sqrt{2}$ 和 $(1,-1)/\sqrt{2}$。截断负特征值后得到

$$3\cdot\frac{1}{2}\begin{bmatrix}1&1\\1&1\end{bmatrix}=\frac{3}{2}\begin{bmatrix}1&1\\1&1\end{bmatrix}.$$

一次投影需要一次完整的特征分解，代价约 $O(n^3)$，这决定了这类方法能处理的矩阵阶数。

20.1 二次规划
20.2 锥规划
20.3 等价改写
20.4 半正定松弛
20.5 模型与求解方法
20.6 本章小结

选择的依据　选择模型时可以按下面的顺序问。

1. 问题是否凸？不凸的话，改写不会改变这一点，只能走局部方法或松弛。
2. 能否停留在最内层的模型？线性约束的凸二次问题就用二次规划，不要因为通用求解器方便而升级。
3. 数据有什么结构？稀疏、低秩或只能做矩阵向量积，决定是否可以分解，也决定内点法和一阶方法哪个更合算。
4. 需要什么样的结论？只要一个好的解，局部方法足够；需要全局证据，就要付出松弛和对偶验证的代价。

无论走哪条路，得到结果后都要分别核对，如图 20.24所示。等价改写的解丢弃辅助变量后可以直接用，松弛的解则要先恢复再验证。

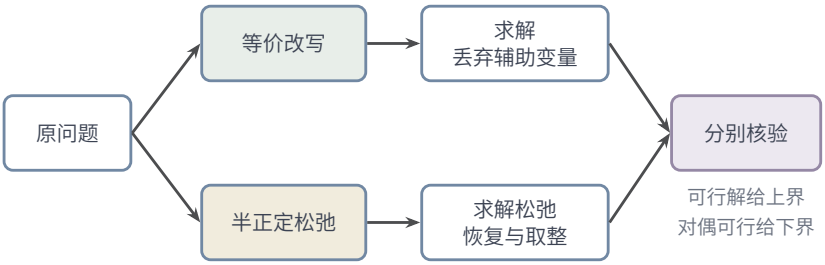


图 20.24　从原问题到可靠结论的两条路径。等价改写（绿）保持最优解，求解后丢弃辅助变量。半正定松弛（黄）扩大可行集，求解后要恢复原变量。两条路径最后都要分别核验：可行解给出上界，对偶可行解给出下界。

20.6　本章小结

章首的三件事现在有了各自的归属。带预算的最小二乘是凸二次规划，距离上限的交集是二阶锥规划，相关系数的可行范围由半正定约束决定。把问题写成这些标准形式，是为了把目标的曲率、可行集的形状和可检验的对偶界摆到明面上。

二次规划要看的是 $\boldsymbol{Q}$ 在可行差方向上的曲率，而不是全空间。这一曲率决定凸性和唯一性；凸时 KKT 条件是全局证书，非凸时 KKT 点可以是局部极小点或鞍点，证书不再成立。等式约束的情形化为线性方程，方程可逆只保证驻点唯一，极小性还要看约化 Hessian。

锥规划把非负约束换成闭凸锥，乘子换成对偶锥的元素。弱对偶无条件成立，给出的下界可以直接验证；强对偶和最优解的达到则需要严格可行性等条件，线性规划的结论不能原样搬到半正定规划。

表 20.10比较后半章的两种操作。

	等价改写	半正定松弛
可行集	投影后与原集合相同	严格扩大（一般情形）
最优值	相等	不超过原最优值
恢复原变量	丢弃辅助变量	秩一时直接读出，否则取整
所需核对	改写的两个方向	可行性、对偶可行性、间隙
典型工具	上图形式、Schur 补	提升、删秩、随机取整

表 20.10　等价改写与半正定松弛的对比。

算法返回的矩阵、原问题的可行解和最优性证书是三样不同的东西，需要分别检查。松弛最优矩阵不一定对应可行点，近似的原始值不是下界，只有经原约束核对的点给出上界，只有对偶可行的解给出下界，两者之差才是可以报告的结论。

第 21 章

可行迭代

把一单位预算分给三个项目，x_i 是第 i 个项目分到的比例。比例不能为负，三者之和必须为一，所以允许的分配构成一个三角形。假设方案的代价是下面的二次函数，三个系数表示各项目偏离理想份额时代价增长的快慢：

$$f(\boldsymbol{x}) = \frac{1}{2}\Big[(x_1 - 1)^2 + 4\big(x_2 - \tfrac{5}{8}\big)^2 + 2x_3^2\Big]. \tag{21.1}$$

理想份额 $(1, \frac{5}{8}, 0)$ 的和是 $\frac{13}{8}$，预算不够，所以约束一定起作用。梯度和 Hessian 分别是

$$\nabla f(\boldsymbol{x}) = \big(x_1 - 1,\ 4x_2 - \tfrac{5}{2},\ 2x_3\big), \qquad \nabla^2 f = \operatorname{diag}(1, 4, 2).$$

于是光滑常数 $L = 4$，强凸常数 $\mu = 1$。

这个问题的解是 $\boldsymbol{x}^\star = (\frac{1}{2}, \frac{1}{2}, 0)$，最优值 $f^\star = \frac{5}{32}$，第 21.2.2节会验证这一点。图 21.1把三维空间里的这个三角形摊平画出，三个顶点是把全部预算给一个项目的方案。解落在底边上，第三个项目分不到预算。

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.3 条件梯度法（Frank–Wolfe）
21.4 镜像下降
21.5 广义约化梯度法（GRG）
21.6 方法比较
21.7 本章小结

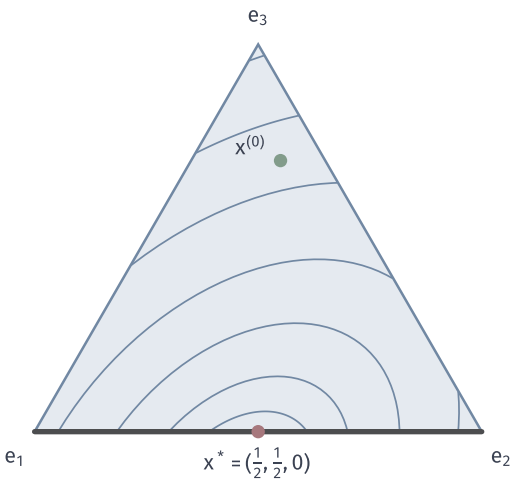


图 21.1　贯穿全章的资源分配例。浅蓝三角形是 $\{\boldsymbol{x} \geq \mathbf{0},\, x_1 + x_2 + x_3 = 1\}$，顶点 $\boldsymbol{e}_i$ 是第 i 个坐标为 1 的单位向量。蓝线是式 (21.1)在三角形上的等高线，绿点是起点 $(0.1, 0.2, 0.7)$，红点是最优解，深灰粗线是活动约束 $x_3 = 0$ 所在的边。

梯度下降的一步会把点带出三角形：坐标和不再是一，某些坐标可能变负。这一章研究的问题是：怎样让每个迭代点都满足原约束，保持可行又要付出多少计算？

第 21.1节先比较可以调用的几种运算。随后三节留在闭凸集合上，用同一个预算问题比较三种走法：先走再拉回最近点，朝线性模型的最优顶点靠拢，以及换一把更贴合比例结构的尺子。第 21.5节转向圆周这样的弯曲约束，这时连接两个可行点的线段不再可行，需要局部消元并解方程回到约束上。最后一节说明这些方法在什么前提下才能放在一起比较，以及算完之后应该报告什么。

21.1 可行集合上的更新

设 $\boldsymbol{C} \subseteq \mathbb{R}^n$ 是非空闭凸集，f 在包含 $\boldsymbol{C}$ 的开集上可微，要解

$$\min_{\boldsymbol{x} \in \boldsymbol{C}} f(\boldsymbol{x}). \tag{21.2}$$

有了当前可行点和它的梯度，还需要关于 $\boldsymbol{C}$ 的什么额外运算，才能算出下一个可行点？

三种集合运算　梯度只描述目标，对集合一无所知。把集合的信息送进更新，最常见的有三个渠道，它们分别回答三个不同的问题。

第一种是**投影**（projection）：给定任意点 $\boldsymbol{z}$，问 $\boldsymbol{C}$ 中离它最近的点在哪里。第二种是线性最小化：给定方向 $\boldsymbol{g}$，问 $\boldsymbol{C}$ 中沿 $-\boldsymbol{g}$ 走得最远的点在哪

里，也就是求 $\min_{s \in C} \langle g, s \rangle$。第三种是用一个由集合结构决定的非欧氏尺度求“最近点”，第 21.4节会定义这把尺子。

图 21.2在预算三角形上取同一个当前点，把三种运算画在一起。投影梯度先离开集合再回来，新点落在边界上；条件梯度沿当前点与顶点的线段移动，新点是两个可行点的组合；镜像更新走一条弯曲的路径，靠近边界时自动减速。

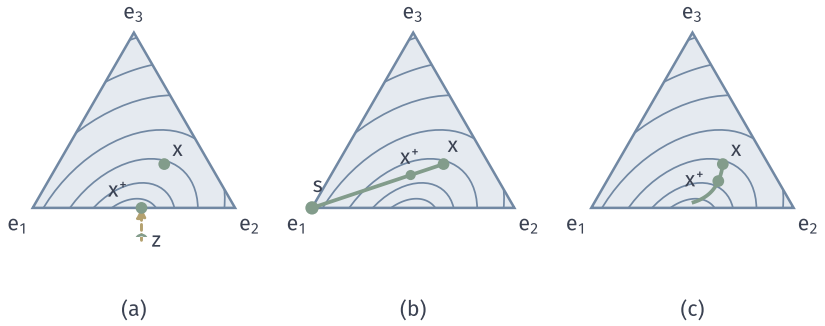


图 21.2 预算三角形上从同一点 $x = (0.225, 0.525, 0.25)$ 出发的三种更新，为看清位移取较大的步长 $\alpha = 0.6$。(a) 投影梯度：绿色箭头是平面内的梯度步，到达三角形外的空心点 z，黄色虚线把它拉回最近点 x^+。(b) 条件梯度：线性模型在顶点 s 处最优，新点是线段上的一点，图中取组合系数 0.25。(c) 镜像更新：绿线是步长从 0 增大时新点的轨迹，它始终留在三角形内部。

凸性给了什么，没给什么 C 凸意味着两个可行点之间的线段仍然可行。这保证条件梯度的组合可行，也保证投影存在唯一。图 21.3(a) 画的就是这种情形。

凸性并不保证子问题便宜。在几千个一般线性不等式定义的多面体上，投影本身就是一个二次规划。在迹为一的半正定矩阵集合上，投影需要完整的特征分解，线性最小化却只需要一个最小特征向量。在单纯形上，投影和线性最小化都很便宜。所以选哪种方法，要先问手上的集合支持哪种运算。

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.2.1 投影计算
21.2.2 投影梯度残差
21.2.3 步长与误差
21.3 条件梯度法（Frank–Wolfe）
21.4 镜像下降
21.5 广义约化梯度法（GRG）
21.6 方法比较
21.7 本章小结

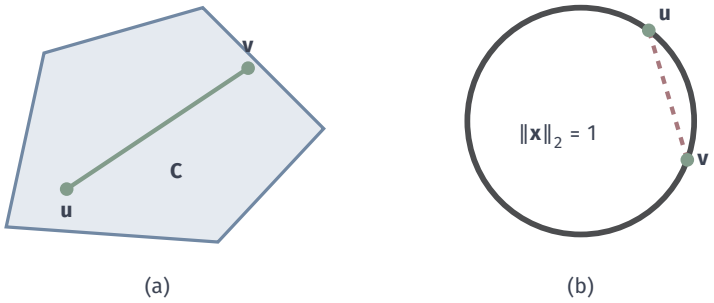


图 21.3 两种可行集合的差别。(a) 凸集 $\mathcal{C}$ 中两点 u, v 的连线（绿色）留在集合内。(b) 圆周 $\|x\|_2 = 1$ 上两点的连线（红色虚线）除端点外全部不可行，沿直线走的任何一步都要再回到圆周上。

各节使用的假设 表 21.1列出后面各节的前提。前三行共用“集合是闭凸的”这一点，具体要求仍各不相同：条件梯度要求集合紧，否则线性子问题可能无解；镜像下降还要求势函数与集合匹配。

表 21.1 本章各方法使用的集合、额外运算与评价量。

方法	集合	额外运算	评价量
投影梯度	非空闭凸	欧氏投影	目标差、残差
条件梯度	非空紧凸	线性最小化	目标差、间隙
镜像下降	闭凸，配势函数	Bregman 子问题	平均点目标差
GRG	光滑等式加界	解方程	约束与 KKT 残差

最后一行与前三行性质不同。图 21.3(b) 的圆周不是凸集，前三种方法的保证都不能搬过去。第 21.5节依靠的是约束在当前点附近的局部可解性：Jacobian 矩阵的一个方块要可逆，解非线性方程要能回到约束上。这些条件要逐点核对，它们失败的方式也和凸情形不同。

21.2 投影梯度法（PGD）

梯度步把点带出可行集合，能不能走完再拉回来，并且仍然保留梯度下降的保证？本节回答这个问题：先算投影，再说明残差应该怎样定义，最后证明下降和收敛。

主要思想 回想第 5章的二次上界。在当前点 x，无约束的梯度步是在全空间最小化上界模型。现在只在 $\mathcal{C}$ 上最小化同一个模型：

$$x^{+} = \arg\min_{y \in \mathcal{C}} \left\{ f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2\alpha} \|y - x\|_2^2 \right\}.$$

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.2.1 投影计算
21.2.2 投影梯度残差
21.2.3 步长与误差
21.3 条件梯度法（Frank–Wolfe）
21.4 镜像下降
21.5 广义约化梯度法（GRG）
21.6 方法比较
21.7 本章小结

把花括号里关于 $\boldsymbol{y}$ 的部分配方，常数项不影响最小点，得到

$$\boldsymbol{x}^{+}=\arg\min_{\boldsymbol{y}\in\boldsymbol{C}}\frac{1}{2\alpha}\left\|\boldsymbol{y}-\left(\boldsymbol{x}-\alpha\nabla f(\boldsymbol{x})\right)\right\|_2^2.$$

这正是求 $\boldsymbol{C}$ 中离梯度步终点最近的点。

记 $\boldsymbol{C}$ 上的欧氏投影为

$$P_{\boldsymbol{C}}(\boldsymbol{z})=\arg\min_{\boldsymbol{y}\in\boldsymbol{C}}\|\boldsymbol{y}-\boldsymbol{z}\|_2, \tag{21.3}$$

投影梯度法（projected gradient descent，PGD）的迭代就是

$$\boldsymbol{x}^{(t+1)}=P_{\boldsymbol{C}}\left(\boldsymbol{x}^{(t)}-\alpha^{(t)}\boldsymbol{g}^{(t)}\right). \tag{21.4}$$

第 11章把投影看作约束指标函数的邻近映射，这里复述要用到的三条结论。对非空闭凸集，投影存在且唯一；$\boldsymbol{p}=P_{\boldsymbol{C}}(\boldsymbol{z})$ 当且仅当 $\boldsymbol{p}\in\boldsymbol{C}$ 且

$$\langle\boldsymbol{z}-\boldsymbol{p},\boldsymbol{y}-\boldsymbol{p}\rangle\le 0,\quad\forall\boldsymbol{y}\in\boldsymbol{C}; \tag{21.5}$$

投影不会拉大距离，也就是

$$\|P_{\boldsymbol{C}}(\boldsymbol{u})-P_{\boldsymbol{C}}(\boldsymbol{v})\|_2\le\|\boldsymbol{u}-\boldsymbol{v}\|_2. \tag{21.6}$$

式 (21.5)有直观的几何含义：从 $\boldsymbol{p}$ 看，$\boldsymbol{z}$ 和集合中任何一点的夹角都不小于直角。就像站在池塘边离某棵树最近的位置，整个池塘都在你身后的半边。

21.2.1 投影计算

式 (21.4)的数学形式对所有闭凸集相同，能不能算则要看集合。本小节算出两个最常用的投影，并把预算例走几步。

盒约束 设 $\boldsymbol{C}=\{\boldsymbol{x}:\boldsymbol{l}\le\boldsymbol{x}\le\boldsymbol{u}\}$。目标 $\sum_i(y_i-z_i)^2$ 和约束都按坐标分离，所以每个坐标单独处理：

$$P_{\boldsymbol{C}}(\boldsymbol{z})_i=\min\{u_i,\max\{l_i,z_i\}\}. \tag{21.7}$$

例如 $\boldsymbol{C}=[0,1]^2$ 时，$(1.4,-0.3)$ 的投影是 $(1,0)$。计算量是 $O(n)$。

单纯形 设 $\boldsymbol{\Delta}$ 是 n 维概率单纯形：

$$\boldsymbol{\Delta}=\{\boldsymbol{x}\in\mathbb{R}^n:\boldsymbol{x}\ge\boldsymbol{0},\ \boldsymbol{1}^{\top}\boldsymbol{x}=1\}. \tag{21.8}$$

坐标和的约束把各坐标绑在一起，不能逐坐标截断。写出投影子问题：

$$\min_{\boldsymbol{p}} \ \frac{1}{2}\|\boldsymbol{p}-\boldsymbol{z}\|_2^2, \qquad \mathbf{1}^\top \boldsymbol{p} = 1, \quad \boldsymbol{p} \ge \mathbf{0}.$$

这是约束都为线性的凸问题，KKT 条件既必要又充分，详见第 17章。

对等式引入乘子 ν，对 $p_i \ge 0$ 引入乘子 $\lambda_i \ge 0$，KKT 条件是

$$p_i - z_i + \nu - \lambda_i = 0, \qquad \lambda_i p_i = 0.$$

下面分两种情况。若 $p_i > 0$，则 $\lambda_i = 0$，于是 $p_i = z_i - \nu$，这要求 $z_i > \nu$。若 $p_i = 0$，则 $\lambda_i = \nu - z_i \ge 0$，这要求 $z_i \le \nu$。

两种情况合起来，所有坐标共用一个阈值 ν：

$$p_i = \max\{z_i - \nu, 0\}, \qquad \varphi(\nu) := \sum_{i=1}^{n} \max\{z_i - \nu, 0\} = 1. \tag{21.9}$$

φ 连续、不增，在取正值的范围内严格递减，$\nu \to -\infty$ 时趋于无穷，ν 足够大时为零，所以方程 $\varphi(\nu) = 1$ 恰有一个解。

可以把 z_i 想成并排的水柱，ν 是一条水平刻度线，刻度线以上的部分就是分到的份额。把刻度线上下移动，直到露出部分的总量恰好是一。低于刻度线的项目一点也分不到。图 21.4是这个图景。

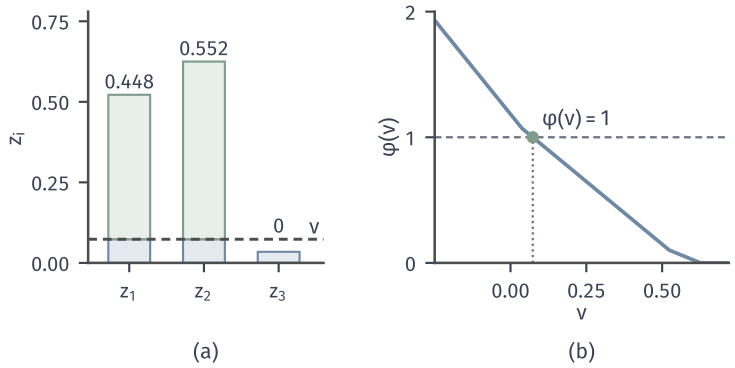


图 21.4　单纯形投影的统一阈值，输入 $\boldsymbol{z} = (0.521875, 0.625, 0.034375)$。(a) 虚线是阈值 ν，绿色部分是投影结果，第三个柱子低于阈值，分到 0。(b)$\varphi(\nu)$ 是分段线性的递减折线，在每个 z_i 处转折，绿点是 $\varphi(\nu) = 1$ 的解 $\nu = 0.0734375$。

求阈值　把 $\boldsymbol{z}$ 从大到小排序为 $z_{(1)} \ge \cdots \ge z_{(n)}$。若恰好前 k 个坐标取正，方程 (21.9)给出

$$\nu_k = \frac{1}{k}\Big(\sum_{j=1}^{k} z_{(j)} - 1\Big).$$

正确的 k 是满足 $z_{(k)} > \nu_k$ 的最大下标。计算量由排序决定，是 $O(n \log n)$。

用图 21.4的数据演示。先试 $k=3$，$\nu_3=(1.18125-1)/3\approx 0.0604$，而最小的坐标 $0.034375<0.0604$，不满足要求。再试 $k=2$：

$$\nu_2=\frac{0.521875+0.625-1}{2}=0.0734375.$$

这次 $z_{(2)}=0.521875>\nu_2$，所以 $k=2$，投影是

$$\boldsymbol{p}=(0.4484375,\ 0.5515625,\ 0).$$

投影不是归一化 把 $\boldsymbol{z}$ 除以坐标和也能得到和为一的向量，但这是另一个运算。取 $\boldsymbol{z}=(0.325,0.625,0.35)$，坐标和 1.3，归一化得到 $(0.25,0.481,0.269)$；投影的阈值是 $\nu=0.1$，结果是 $(0.225,0.525,0.25)$。投影按相同的量减少各坐标，归一化按相同的比例缩小各坐标。

坐标有负值时差别更大。$\boldsymbol{z}'=(0.9,0.5,-0.4)$ 的坐标和恰好是一，归一化什么也不做，结果仍然不可行。投影取阈值 $\nu=0.2$，得到 $(0.7,0.3,0)$。图 21.5(c) 在两个坐标的情形画出这种差别：归一化沿过原点的射线回到直线，只有投影沿垂线回来。

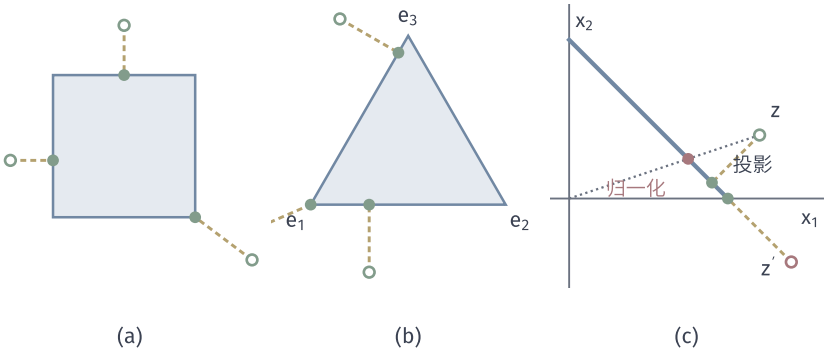


图 21.5 投影的几何。空心点是输入，实心绿点是投影，黄色虚线是拉回的路径。(a) 盒子 $[0,1]^2$：逐坐标截断，右下方的点落在角上。(b) 单纯形：输入点在三角形所在平面内，可能落到边上，也可能落到顶点。(c) 两个坐标的单纯形（蓝线段）：$\boldsymbol{z}$ 的投影与归一化结果（红点，沿过原点的点线）不同；$\boldsymbol{z}'$ 的坐标和已为一，归一化不改变它，它仍然不可行，投影把它送到端点。

昂贵的投影 集合复杂时投影没有公式。在 $\{\boldsymbol{x}:\boldsymbol{A}\boldsymbol{x}\le\boldsymbol{b}\}$ 上，式 (21.3)就是一个有 m 个不等式的二次规划，需要用第 20章的算法迭代求解。这时外层每一步都包着一个内层优化，内层只能算到有限精度，第 21.2.3节会讨论由此带来的误差。

变量

- $\boldsymbol{x}^{(t)} \in \boldsymbol{C}$：当前可行点。
- $\boldsymbol{g}^{(t)} \in \mathbb{R}^n$：当前梯度。
- $\boldsymbol{z}^{(t)} \in \mathbb{R}^n$：梯度步的终点，通常不可行。
- $\alpha > 0$：步长；$\varepsilon > 0$ 与 T：容差与最大步数。

初始化 取可行起点 $\boldsymbol{x}^{(0)} \in \boldsymbol{C}$，步长 $\alpha \le 1/L$，令 $t = 0$。例中用式 (21.1)，取 $\alpha = 1/L = 1/4$，容差 $\varepsilon = 10^{-3}$，起点和目标值是

$$\boldsymbol{x}^{(0)} = (0.1, 0.2, 0.7), \qquad f(\boldsymbol{x}^{(0)}) = 1.25625.$$

每轮更新 在第 t 轮：

1. **计算梯度步**。令 $\boldsymbol{z}^{(t)} = \boldsymbol{x}^{(t)} - \alpha \boldsymbol{g}^{(t)}$。例中第一轮

$$\boldsymbol{g}^{(0)} = (-0.9, -1.7, 1.4), \qquad \boldsymbol{z}^{(0)} = (0.325, 0.625, 0.35).$$

2. **投影**。由式 (21.9)得 $\boldsymbol{x}^{(t+1)} = P_{\boldsymbol{C}}(\boldsymbol{z}^{(t)})$。例中第一轮坐标和 1.3，$k = 3$，阈值 $\nu = 0.1$，于是

$$\boldsymbol{x}^{(1)} = (0.225, 0.525, 0.25), \qquad f(\boldsymbol{x}^{(1)}) \approx 0.38281.$$

3. **检查停止**。若相邻两点之差的长度除以 α 不超过 ε，或 $t + 1 = T$，输出 $\boldsymbol{x}^{(t+1)}$；否则 $t \leftarrow t + 1$。例中第一轮这个量约为 2.28，继续。

   例中第二轮，$\boldsymbol{g}^{(1)} = (-0.775, -0.4, 0.5)$，梯度步终点和投影依次是

$$\boldsymbol{z}^{(1)} = (0.41875, 0.625, 0.125), \qquad \boldsymbol{x}^{(2)} = (0.3625, 0.56875, 0.06875).$$

这一轮 $\nu = 0.05625$，三个坐标仍然为正，$f(\boldsymbol{x}^{(2)}) \approx 0.21426$。

例中第三轮，$\boldsymbol{g}^{(2)} = (-0.6375, -0.225, 0.1375)$，梯度步终点是图 21.4用过的 $\boldsymbol{z}^{(2)}$。前面已算出 $\nu = 0.0734375$，第三个坐标被截到零：

$$\boldsymbol{x}^{(3)} = (0.4484375, 0.5515625, 0), \qquad f(\boldsymbol{x}^{(3)}) \approx 0.16290.$$

此后迭代留在底边上。由 $x_3 = 0$ 和 $x_2 = 1 - x_1$ 代入，每轮的投影化成一维递推

$$x_1^{(t+1)} = \tfrac{3}{8} x_1^{(t)} + \tfrac{5}{16}, \qquad t \ge 3,$$

不动点是 $x_1 = \tfrac{1}{2}$，误差每轮乘以 $\tfrac{3}{8}$。

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.2.1 投影计算
21.2.2 投影梯度残差
21.2.3 步长与误差
21.3 条件梯度法（Frank–Wolfe）
21.4 镜像下降
21.5 广义约化梯度法（GRG）
21.6 方法比较
21.7 本章小结

第 10 轮的更新量降到容差以下，最终得到 $\boldsymbol{x}^{(10)} \approx (0.49995, 0.50005, 0)$。图 21.6(a) 是这条路径，第三步落到活动边之后再也没有离开。

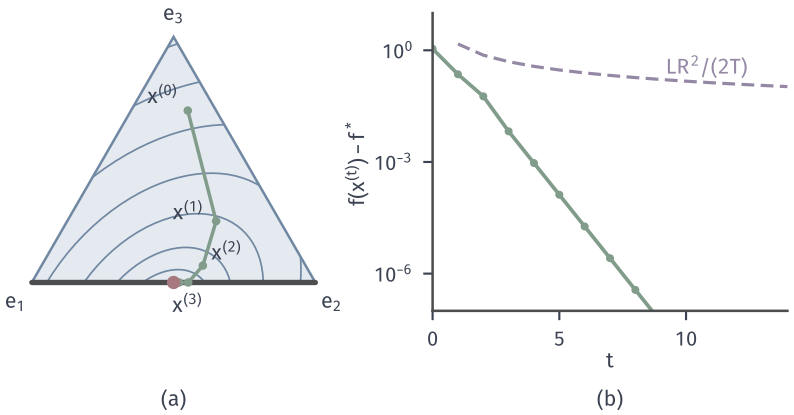


图 21.6 预算例上的投影梯度法，$\alpha = 1/4$，起点 $(0.1, 0.2, 0.7)$。(a) 绿色路径在第三步到达活动边（深灰），红点是最优解。(b) 绿线是实际目标差，紫色虚线是第 21.2.3节证明的上界 $LR^2/(2T)$，$R^2 = \|\boldsymbol{x}^{(0)} - \boldsymbol{x}^\star\|_2^2 = 0.74$。这个例子强凸，实际收敛比 $1/T$ 快得多。

21.2.2 投影梯度残差

无约束时用 $\|\nabla f\|_2$ 判断停止。有约束时这把尺子失灵：预算例的最优解处 $\nabla f(\boldsymbol{x}^\star) = (-\tfrac{1}{2}, -\tfrac{1}{2}, 0)$ 并不为零。那么应该用什么量来判断“已经到了”？

残差的定义 一个点走不动，意思是走一步再投影又回到原地。把这个位移除以步长，单位就和梯度一致。

定义 21.1 投影梯度残差 设 $\alpha > 0$，$\boldsymbol{x} \in \boldsymbol{C}$。称

$$\boldsymbol{G}_\alpha(\boldsymbol{x}) = \frac{1}{\alpha}\Big[\boldsymbol{x} - P_{\boldsymbol{C}}\big(\boldsymbol{x} - \alpha \nabla f(\boldsymbol{x})\big)\Big] \tag{21.10}$$

为**投影梯度残差**（projected gradient residual）。

$\boldsymbol{C} = \mathbb{R}^n$ 时投影不起作用，$\boldsymbol{G}_\alpha = \nabla f$，所以它是梯度的推广。第 21.2.1节的停止量正是 $\|\boldsymbol{G}_\alpha(\boldsymbol{x}^{(t)})\|_2$。

残差为零意味着什么 凸集上的一阶必要条件是下面的**变分不等式**（variational inequality）：对可行方向 $\boldsymbol{y} - \boldsymbol{x}$，目标的方向导数不能为负。推导很短：若 $\boldsymbol{x}$ 是局部极小点，$\boldsymbol{y} \in \boldsymbol{C}$，线段 $\boldsymbol{x} + s(\boldsymbol{y} - \boldsymbol{x})$ 在 $s \in [0, 1]$ 上可行，所以

$$0 \le \lim_{s \downarrow 0} \frac{f(\boldsymbol{x} + s(\boldsymbol{y} - \boldsymbol{x})) - f(\boldsymbol{x})}{s} = \langle \nabla f(\boldsymbol{x}), \boldsymbol{y} - \boldsymbol{x} \rangle.$$

定理 21.2　残差为零与变分不等式　设 $\boldsymbol{C}$ 非空闭凸，f 在 $\boldsymbol{x}\in\boldsymbol{C}$ 处可微，$\alpha>0$。则 $\boldsymbol{G}_\alpha(\boldsymbol{x})=\boldsymbol{0}$ 当且仅当

$$\langle \nabla f(\boldsymbol{x}),\boldsymbol{y}-\boldsymbol{x}\rangle \ge 0,\quad \forall \boldsymbol{y}\in\boldsymbol{C}. \tag{21.11}$$

若 f 还是凸函数，这又等价于 $\boldsymbol{x}$ 是 f 在 $\boldsymbol{C}$ 上的全局最优解。

证明　$\boldsymbol{G}_\alpha(\boldsymbol{x})=\boldsymbol{0}$ 就是 $\boldsymbol{x}=P_{\boldsymbol{C}}(\boldsymbol{x}-\alpha\nabla f(\boldsymbol{x}))$。在式 (21.5)中取 $\boldsymbol{p}=\boldsymbol{x}$，$\boldsymbol{z}=\boldsymbol{x}-\alpha\nabla f(\boldsymbol{x})$，这等价于

$$\langle -\alpha\nabla f(\boldsymbol{x}),\boldsymbol{y}-\boldsymbol{x}\rangle \le 0,\quad \forall \boldsymbol{y}\in\boldsymbol{C}.$$

除以 $-\alpha<0$，不等号反向，即得式 (21.11)。

f 凸时，切平面从下方托住目标，所以

$$f(\boldsymbol{y})\ge f(\boldsymbol{x})+\langle \nabla f(\boldsymbol{x}),\boldsymbol{y}-\boldsymbol{x}\rangle \ge f(\boldsymbol{x}),$$

$\boldsymbol{x}$ 是全局最优解。反方向是前面的一阶必要条件。 ■

条件 (21.11)里没有 α，所以残差对某一个 α 为零，就对所有 $\alpha>0$ 为零。残差的大小则随 α 变化，比较时要固定步长。

边界最优点　现在验证预算例的解。在 $\boldsymbol{x}^\star=(\tfrac12,\tfrac12,0)$ 处，对任意 $\boldsymbol{y}\in\boldsymbol{\Delta}$，利用 $y_1+y_2=1-y_3$，得到

$$\langle \nabla f(\boldsymbol{x}^\star),\boldsymbol{y}-\boldsymbol{x}^\star\rangle = -\tfrac12(y_1+y_2)+\tfrac12 = \tfrac12 y_3\ge 0.$$

变分不等式成立，目标凸，所以 $\boldsymbol{x}^\star$ 是全局最优解。把它代入式 (21.1)，得到

$$f^\star=\tfrac12\big[\tfrac14+\tfrac{1}{16}\big]=\tfrac{5}{32}.$$

梯度不为零，但它指向的是“出不去”的方向。这就好比一个人靠墙站着，墙外地势更低：坡度不为零，他却走不动。图 21.7对比了两个边界点。最优点的梯度步终点垂直于活动边，投影原路拉回。另一个点的梯度步有沿边的分量，投影之后确实前进了。

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.2.1 投影计算
21.2.2 投影梯度残差
21.2.3 步长与误差
21.3 条件梯度法（Frank–Wolfe）
21.4 镜像下降
21.5 广义约化梯度法（GRG）
21.6 方法比较
21.7 本章小结

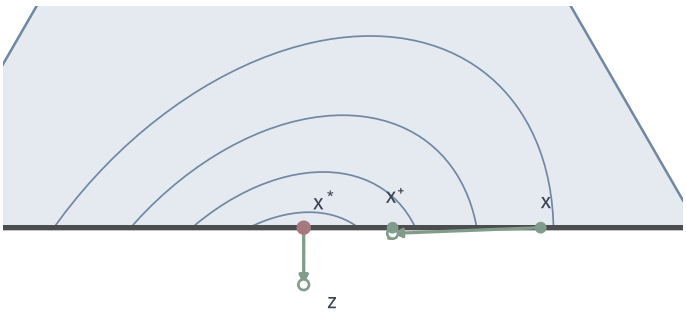


图 21.7 残差在活动边上的含义，局部放大底边，$\alpha = 1/4$。红点 $\boldsymbol{x}^\star$ 处，平面内的梯度步（绿色箭头）垂直离开边，投影回到原处，残差为零而梯度不为零。右侧的 $\boldsymbol{x} = (0.2, 0.8, 0)$ 处，梯度步有沿边分量，投影后到达 $\boldsymbol{x}^+$，残差不为零。

非凸时残差只检验驻定 定理 21.2的后半句依赖凸性。取一元函数 $f(x) = -x^2$，$\boldsymbol{C} = [-1, 2]$。残差为零的点有三个：$x = -1$、$x = 0$、$x = 2$。

图 21.8画出了它们。$x = 0$ 是目标的局部极大点；$x = -1$ 是约束上的局部极小点，$f = -1$；只有 $x = 2$ 是全局最优解，$f = -4$。残差只说明“在一阶意义下走不动”，不区分这三种情况。

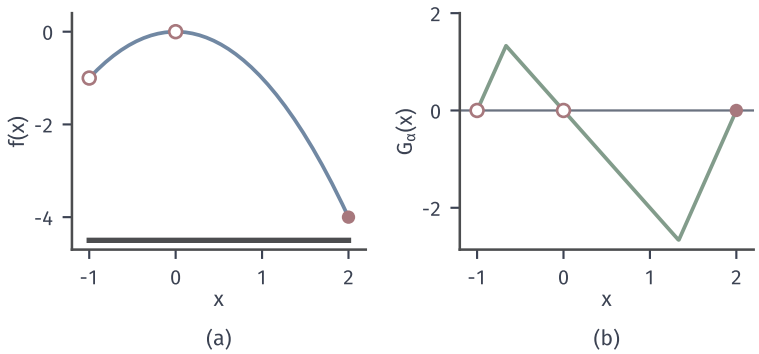


图 21.8 非凸目标 $f(x) = -x^2$，$\boldsymbol{C} = [-1, 2]$（深灰线）。(a) 目标曲线，空心红点是局部极大点 0 和局部极小点 -1，实心红点是全局最优解 2。(b)$\alpha = 1/4$ 时的残差 $G_\alpha(x)$，在这三个点上都为零。

21.2.3 步长与误差

残差为零是目标。迭代是否真的把残差推向零，又需要什么步长？投影只能近似时，保证还剩多少？

单步下降 投影性质 (21.5)告诉我们投影后的位移仍然是一个下降方向，这是下面所有结论的基础。

定理 21.3　投影梯度的单步下降　设 $\boldsymbol{C}$ 非空闭凸，f 在包含 $\boldsymbol{C}$ 的开集上可微，且在 $\boldsymbol{C}$ 上 L 光滑。对 $\boldsymbol{x}\in\boldsymbol{C}$ 和 $\alpha>0$，记 $\boldsymbol{x}^{+}$ 是式 (21.4)的新点，有

$$f(\boldsymbol{x}^{+})\le f(\boldsymbol{x})-\alpha\Big(1-\frac{L\alpha}{2}\Big)\|\boldsymbol{G}_{\alpha}(\boldsymbol{x})\|_2^2. \tag{21.12}$$

证明　在式 (21.5)中取 $\boldsymbol{z}=\boldsymbol{x}-\alpha\nabla f(\boldsymbol{x})$，$\boldsymbol{p}=\boldsymbol{x}^{+}$，$\boldsymbol{y}=\boldsymbol{x}$，得到

$$\langle \boldsymbol{x}-\alpha\nabla f(\boldsymbol{x})-\boldsymbol{x}^{+},\boldsymbol{x}-\boldsymbol{x}^{+}\rangle\le 0.$$

整理后得到投影位移与梯度的内积：

$$\langle \nabla f(\boldsymbol{x}),\boldsymbol{x}^{+}-\boldsymbol{x}\rangle\le-\frac{1}{\alpha}\|\boldsymbol{x}^{+}-\boldsymbol{x}\|_2^2.$$

$\boldsymbol{C}$ 凸，线段 $[\boldsymbol{x},\boldsymbol{x}^{+}]$ 在 $\boldsymbol{C}$ 中，下降引理可用，于是

$$f(\boldsymbol{x}^{+})\le f(\boldsymbol{x})+\langle\nabla f(\boldsymbol{x}),\boldsymbol{x}^{+}-\boldsymbol{x}\rangle+\frac{L}{2}\|\boldsymbol{x}^{+}-\boldsymbol{x}\|_2^2.$$

把前一式代入，再用 $\boldsymbol{x}^{+}-\boldsymbol{x}=-\alpha\boldsymbol{G}_{\alpha}(\boldsymbol{x})$，即得式 (21.12)。 ■

只要 $0<\alpha<2/L$，式 (21.12)的括号就是正的，目标严格下降，除非已经驻定。这和无约束的下降估计形式完全相同，只是把梯度换成了残差。

非凸问题　目标非凸时目标差无从谈起，能评价的是残差。这里需要目标在集合上有下界，否则下降可以无休止地进行。

定理 21.4　非凸情形的投影梯度　在定理 21.3的条件下，设 $f_{\inf}=\inf_{\boldsymbol{C}} f>-\infty$，取 $\alpha=1/L$，则对 $T\ge 1$，

$$\min_{0\le t<T}\|\boldsymbol{G}_{\alpha}(\boldsymbol{x}^{(t)})\|_2^2\le\frac{2L\big(f(\boldsymbol{x}^{(0)})-f_{\inf}\big)}{T}, \tag{21.13}$$

并且 $\{\boldsymbol{x}^{(t)}\}$ 的每个极限点都满足变分不等式 (21.11)。

证明　由式 (21.12)，$\alpha=1/L$ 时

$$\frac{1}{2L}\|\boldsymbol{G}_{\alpha}(\boldsymbol{x}^{(t)})\|_2^2\le f(\boldsymbol{x}^{(t)})-f(\boldsymbol{x}^{(t+1)}).$$

对 $t=0,\dots,T-1$ 求和，右端裂项，并用 $f(\boldsymbol{x}^{(T)})\ge f_{\inf}$，最小值不超过平均值，即得式 (21.13)。

级数 $\sum_t \|\boldsymbol{G}_\alpha(\boldsymbol{x}^{(t)})\|_2^2$ 收敛，所以残差趋于零。若梯度连续，投影非扩张保证 $\boldsymbol{G}_\alpha$ 连续，极限点处残差为零。定理 21.2给出结论。 ■

凸问题　加上凸性和解的存在，可以用目标差衡量。证明的关键是把一步的目标差写成到解距离平方的差，这样求和时能够裂项。

定理 21.5　凸情形的投影梯度　在定理 21.3的条件下，设 f 在 $\boldsymbol{C}$ 上凸，且存在最优解 $\boldsymbol{x}^\star \in \boldsymbol{C}$，取 $\alpha = 1/L$。则对 $T \ge 1$，

$$f(\boldsymbol{x}^{(T)}) - f^\star \le \frac{L\|\boldsymbol{x}^{(0)} - \boldsymbol{x}^\star\|_2^2}{2T}. \tag{21.14}$$

若 f 还在 $\boldsymbol{C}$ 上 μ 强凸，$\mu > 0$，则

$$\|\boldsymbol{x}^{(t+1)} - \boldsymbol{x}^\star\|_2^2 \le \Big(1 - \frac{\mu}{L}\Big)\|\boldsymbol{x}^{(t)} - \boldsymbol{x}^\star\|_2^2. \tag{21.15}$$

证明　记 $\boldsymbol{x} = \boldsymbol{x}^{(t)}$，$\boldsymbol{x}^+ = \boldsymbol{x}^{(t+1)}$，$\boldsymbol{g} = \nabla f(\boldsymbol{x})$，$\boldsymbol{y} \in \boldsymbol{C}$ 任取。由下降引理和 μ 强凸的下界（$\mu = 0$ 即凸），得到

$$f(\boldsymbol{x}^+) \le f(\boldsymbol{x}) + \langle \boldsymbol{g}, \boldsymbol{x}^+ - \boldsymbol{x}\rangle + \frac{L}{2}\|\boldsymbol{x}^+ - \boldsymbol{x}\|_2^2,$$
$$f(\boldsymbol{y}) \ge f(\boldsymbol{x}) + \langle \boldsymbol{g}, \boldsymbol{y} - \boldsymbol{x}\rangle + \frac{\mu}{2}\|\boldsymbol{y} - \boldsymbol{x}\|_2^2.$$

两式相减，消去 $f(\boldsymbol{x})$：

$$f(\boldsymbol{x}^+) - f(\boldsymbol{y}) \le \langle \boldsymbol{g}, \boldsymbol{x}^+ - \boldsymbol{y}\rangle + \frac{L}{2}\|\boldsymbol{x}^+ - \boldsymbol{x}\|_2^2 - \frac{\mu}{2}\|\boldsymbol{y} - \boldsymbol{x}\|_2^2.$$

在式 (21.5)中取 $\boldsymbol{z} = \boldsymbol{x} - \boldsymbol{g}/L$，$\boldsymbol{p} = \boldsymbol{x}^+$，整理得

$$\langle \boldsymbol{g}, \boldsymbol{x}^+ - \boldsymbol{y}\rangle \le L\langle \boldsymbol{x} - \boldsymbol{x}^+, \boldsymbol{x}^+ - \boldsymbol{y}\rangle.$$

再用恒等式展开 $\|\boldsymbol{x} - \boldsymbol{y}\|_2^2$，它把内积化成三个距离平方：

$$2\langle \boldsymbol{x} - \boldsymbol{x}^+, \boldsymbol{x}^+ - \boldsymbol{y}\rangle = \|\boldsymbol{x} - \boldsymbol{y}\|_2^2 - \|\boldsymbol{x} - \boldsymbol{x}^+\|_2^2 - \|\boldsymbol{x}^+ - \boldsymbol{y}\|_2^2.$$

代回去，$\|\boldsymbol{x}^+ - \boldsymbol{x}\|_2^2$ 的项抵消，得到

$$f(\boldsymbol{x}^+) - f(\boldsymbol{y}) \le \frac{L - \mu}{2}\|\boldsymbol{x} - \boldsymbol{y}\|_2^2 - \frac{L}{2}\|\boldsymbol{x}^+ - \boldsymbol{y}\|_2^2.$$

取 $\boldsymbol{y}=\boldsymbol{x}^\star$，左端非负，移项除以 $L/2$，就是式 (21.15)；$\mu=0$ 时说明到解的距离不增。

$\mu=0$ 时对 $t=0,\dots,T-1$ 求和，右端裂项：

$$\sum_{t=1}^{T}\bigl(f(\boldsymbol{x}^{(t)})-f^\star\bigr)\le\frac{L}{2}\|\boldsymbol{x}^{(0)}-\boldsymbol{x}^\star\|_2^2.$$

由定理 21.3目标逐步下降，最后一项最小，不超过平均值，即得式 (21.14)。 ■

预算例中 $R^2=0.74$，$L=4$，上界是 $1.48/T$，$T=1$ 时为 1.48，实际目标差是 0.2266。强凸的保证给出距离平方每步至少乘以 $\frac{3}{4}$。实际到达活动边之后因子是 $(\frac{3}{8})^2\approx0.14$。约束把自由度减到一维，沿边方向 $(1,-1,0)$ 的曲率是 $\frac{5}{2}$，比全空间最小的曲率 $\mu=1$ 大。

L 未知时　可以用回溯代替固定步长：试探 α，算出 $\boldsymbol{x}^+$，检查

$$f(\boldsymbol{x}^+)\le f(\boldsymbol{x})+\langle\nabla f(\boldsymbol{x}),\boldsymbol{x}^+-\boldsymbol{x}\rangle+\frac{1}{2\alpha}\|\boldsymbol{x}^+-\boldsymbol{x}\|_2^2,$$

不满足就缩短 α。上面的证明只用到这个不等式，结论把 L 换成 $1/\alpha_{\min}$ 仍成立。要注意，换一次 α 就要重新投影，集合复杂时这是真实的成本。

近似投影　投影由内层迭代求出时，输出 $\tilde{\boldsymbol{x}}^+$ 与真投影有差距。设

$$\bigl\|\tilde{\boldsymbol{x}}^+-P_{\boldsymbol{C}}(\boldsymbol{x}-\alpha\nabla f(\boldsymbol{x}))\bigr\|_2\le\varepsilon_t.$$

这个误差有三种影响，要分别看待。

第一是可行性。输出到 $\boldsymbol{C}$ 的距离不超过 ε_t，但不一定是零，所以要单独检查原约束的残差。

第二是误差传播。设 f 的光滑、强凸条件在含所有迭代点的凸集上成立，定理 21.5说明精确映射把到解的距离至少缩小到 $\rho=\sqrt{1-\mu/L}$ 倍。再加上三角不等式，得到

$$\|\boldsymbol{x}^{(t+1)}-\boldsymbol{x}^\star\|_2\le\rho\|\boldsymbol{x}^{(t)}-\boldsymbol{x}^\star\|_2+\varepsilon_t. \tag{21.16}$$

$\varepsilon_t\equiv\varepsilon$ 时展开递推，几何级数求和，距离的上极限不超过 $\varepsilon/(1-\rho)$，迭代停在一个与内层精度成比例的范围里。没有强凸时 $\rho=1$，上界只能写成 $\|\boldsymbol{x}^{(0)}-\boldsymbol{x}^\star\|_2+\sum_t\varepsilon_t$，误差必须可求和才不累积。

第三是残差本身。用近似投影算出的残差 $\tilde{\boldsymbol{G}}_\alpha$ 满足

$$\left|\|\tilde{\boldsymbol{G}}_\alpha\|_2 - \|\boldsymbol{G}_\alpha\|_2\right| \le \frac{\varepsilon_t}{\alpha}.$$

所以步长越小，停止量受内层误差的污染越重。图 21.9显示了前两种影响。预算例中 $\rho \approx 0.866$，$1/(1-\rho) \approx 7.46$。

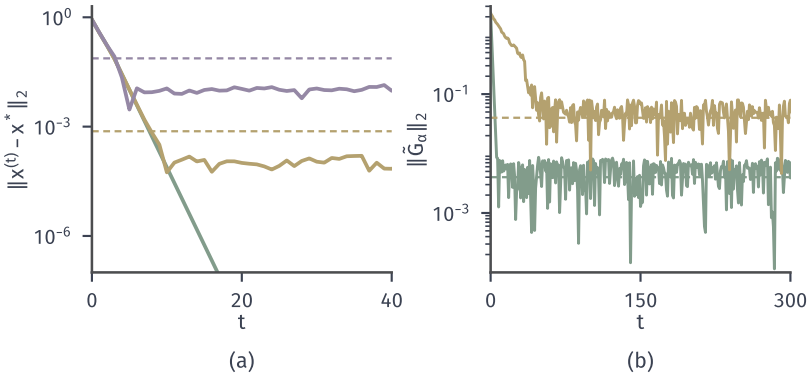


图 21.9 近似投影的影响，在每次投影结果上叠加固定种子的随机扰动，长度为 ε。(a) 到解的距离：绿线是精确投影，黄线 $\varepsilon = 10^{-4}$，紫线 $\varepsilon = 10^{-2}$，同色虚线是上界 $\varepsilon/(1-\rho)$；距离停在上界之内。(b)$\varepsilon = 10^{-3}$ 时算出的残差：绿线 $\alpha = 1/4$，黄线 $\alpha = 1/40$，同色虚线是 ε/α；步长小，平台反而高。

接近可行不等于接近最优 内层把“输出离集合多远”算得很准，不能说明外层接近了解。预算例的顶点 $\boldsymbol{e}_2 = (0,1,0)$ 完全可行，可行误差为零，它的目标差却是 0.625。可行性和最优性是两件事，都要报告。

21.3 条件梯度法（Frank–Wolfe）

投影的代价可能很高，而同一个集合上的线性函数却容易最小化。能不能完全不做投影，只靠线性最小化来保持可行？本节回答这个问题：**条件梯度法**（conditional gradient method）也称**Frank–Wolfe 法**（Frank–Wolfe method）[1]。，它要求集合紧，用目标的一阶信息挑选集合的极点，再用凸组合保持可行。

主要思想 把目标在当前点线性化，$f(\boldsymbol{x}) + \langle \boldsymbol{g}, \boldsymbol{s} - \boldsymbol{x} \rangle$。线性模型没有碗底，无约束时可以降到负无穷，这正是梯度下降要加二次项的原因。现在集合是紧的，线性模型在集合上有最小点，所以可以直接问：只信线性模型的话，集合里哪个点最好？

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.3 条件梯度法（Frank–Wolfe）
21.3.1 线性子问题
21.3.2 步长与可行性
21.3.3 Frank–Wolfe 间隙
21.3.4 活跃顶点的调整（补充）
21.4 镜像下降
21.5 广义约化梯度法（GRG）
21.6 方法比较
21.7 本章小结

[1] M. Frank, P. Wolfe, *An Algorithm for Quadratic Programming* In Naval Research Logistics Quarterly, 1956, vol. 3, no. 1–2, pp. 95–110

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.3 条件梯度法（Frank–Wolfe）
21.3.1 线性子问题
21.3.2 步长与可行性
21.3.3 Frank–Wolfe 间隙
21.3.4 活跃顶点的调整（补充）
21.4 镜像下降
21.5 广义约化梯度法（GRG）
21.6 方法比较
21.7 本章小结

这个点 $\boldsymbol{s}^{(t)}$ 通常在集合的远端，线性模型不能信到那么远。于是不跳过去，只沿连线走一段：

$$\begin{aligned} \boldsymbol{s}^{(t)} &\in \arg\min_{\boldsymbol{s}\in\boldsymbol{C}} \langle \boldsymbol{g}^{(t)}, \boldsymbol{s}\rangle, \\ \boldsymbol{x}^{(t+1)} &= \boldsymbol{x}^{(t)} + \alpha^{(t)}\big(\boldsymbol{s}^{(t)} - \boldsymbol{x}^{(t)}\big), \quad \alpha^{(t)} \in [0,1]. \end{aligned} \tag{21.17}$$

新点是两个可行点的凸组合，所以可行性由 $\alpha^{(t)} \in [0,1]$ 和 $\boldsymbol{C}$ 的凸性保证，不需要任何拉回操作。两种方法的次序相反：投影梯度先走一小步再修正，条件梯度先选定目标位置，再决定走多远。

21.3.1 线性子问题

式 (21.17)的第一行要解一个线性规划。在单纯形上它有闭式解，并且解的形状决定了迭代点的结构。

单纯形上的线性最小化 对任意 $\boldsymbol{s} \in \Delta$，$\boldsymbol{s}$ 的坐标非负且和为一，$\langle \boldsymbol{g}, \boldsymbol{s}\rangle$ 是 g_i 的加权平均，所以

$$\langle \boldsymbol{g}, \boldsymbol{s}\rangle = \sum_{i} s_i g_i \geq \min_i g_i.$$

等号在把全部权重放到最小坐标上时取得。因此线性子问题的一个解是顶点

$$\boldsymbol{s} = \boldsymbol{e}_i, \qquad i \in \arg\min_k g_k. \tag{21.18}$$

只需找出梯度的最小分量，计算量是 $O(n)$，不用排序。

这个结论在任何紧凸集上都有对应：线性函数的最小值总可以在极点处取到。所以线性子问题的解是集合中结构最简单的点。例如迹为一的半正定矩阵集合的极点是秩一矩阵，线性子问题的解就是 $\boldsymbol{v}\boldsymbol{v}^{\mathsf{T}}$，其中 $\boldsymbol{v}$ 是梯度矩阵最小特征值的单位特征向量。

稀疏表示 每轮新点等于旧点乘以 $1-\alpha^{(t)}$，再给选中的顶点加上权重 $\alpha^{(t)}$。若把 $\boldsymbol{x}^{(t)}$ 写成顶点的凸组合，权重的更新就是

$$w_v \leftarrow (1-\alpha^{(t)})w_v, \quad v \neq i; \qquad w_i \leftarrow (1-\alpha^{(t)})w_i + \alpha^{(t)}. \tag{21.19}$$

从一个顶点出发，每轮至多引入一个新顶点，所以 $\boldsymbol{x}^{(t)}$ 至多是 $t+1$ 个顶点的组合。在单纯形上这意味着至多有 $t+1$ 个非零坐标。旧顶点的权重只被等比例缩小，这一点后面会成为问题。

变量

- $\boldsymbol{x}^{(t)} \in \boldsymbol{C}$：当前点；$\boldsymbol{g}^{(t)}$：当前梯度。
- $\boldsymbol{s}^{(t)} \in \boldsymbol{C}$：线性子问题的解，这里是顶点。
- w_v：各活跃顶点的权重，只在需要稀疏表示时保存。
- $\alpha^{(t)} \in [0,1]$：组合系数。

初始化　选一个可行点，通常是一个顶点，令 $t=0$。例中取 $\boldsymbol{x}^{(0)} = \boldsymbol{e}_3 = (0,0,1)$，目标值 $f(\boldsymbol{x}^{(0)}) = 2.28125$，组合系数取预定序列

$$\alpha^{(t)} = \frac{2}{t+2}. \tag{21.20}$$

每轮更新　在第 t 轮：

1. **解线性子问题**。由式 (21.18)选顶点。例中第一轮

$$\boldsymbol{g}^{(0)} = (-1,-2.5,2), \qquad \boldsymbol{s}^{(0)} = \boldsymbol{e}_2.$$

2. **组合**。由式 (21.17)计算新点。例中第一轮 $\alpha^{(0)}=1$，新点直接跳到顶点，$\boldsymbol{e}_3$ 的权重变成零：

$$\boldsymbol{x}^{(1)} = (0,1,0), \qquad f(\boldsymbol{x}^{(1)}) = 0.78125.$$

3. **检查停止**。若 $t+1=T$，输出 $\boldsymbol{x}^{(t+1)}$；否则 $t \leftarrow t+1$。第 21.3.3节会给出可以计算的停止量，例中暂取 $T=100$。

   例中第二轮，$\boldsymbol{g}^{(1)} = (-1,1.5,0)$，选 $\boldsymbol{e}_1$，$\alpha^{(1)} = \frac{2}{3}$，于是

$$\boldsymbol{x}^{(2)} = \left(\tfrac{2}{3},\tfrac{1}{3},0\right), \qquad f(\boldsymbol{x}^{(2)}) \approx 0.22569.$$

   例中第三轮，$\boldsymbol{g}^{(2)} = (-\tfrac{1}{3},-\tfrac{7}{6},0)$，选 $\boldsymbol{e}_2$，$\alpha^{(2)} = \frac{1}{2}$，于是

$$\boldsymbol{x}^{(3)} = \left(\tfrac{1}{3},\tfrac{2}{3},0\right), \qquad f(\boldsymbol{x}^{(3)}) \approx 0.22569.$$

   例中第四轮，$\boldsymbol{g}^{(3)} = (-\tfrac{2}{3},\tfrac{1}{6},0)$，选 $\boldsymbol{e}_1$，$\alpha^{(3)} = \frac{2}{5}$，于是

$$\boldsymbol{x}^{(4)} = \left(\tfrac{3}{5},\tfrac{2}{5},0\right), \qquad f(\boldsymbol{x}^{(4)}) = 0.18125.$$

规律已经出现：两个顶点轮流被选中，迭代点在解 $(\frac{1}{2},\frac{1}{2},0)$ 的两侧来回摆动，幅度慢慢变小。最终在 $T=100$ 得到的点，目标差约为 6.1×10^{-5}。

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.3 条件梯度法（Frank–Wolfe）
21.3.1 线性子问题
21.3.2 步长与可行性
21.3.3 Frank–Wolfe 间隙
21.3.4 活跃顶点的调整（补充）
21.4 镜像下降
21.5 广义约化梯度法（GRG）
21.6 方法比较
21.7 本章小结

图 21.10画出路径和权重。第一步把起点的权重清零，这是 $\alpha^{(0)}=1$ 的特殊效果。之后的权重在 $\boldsymbol{e}_1$ 和 $\boldsymbol{e}_2$ 之间来回转移。

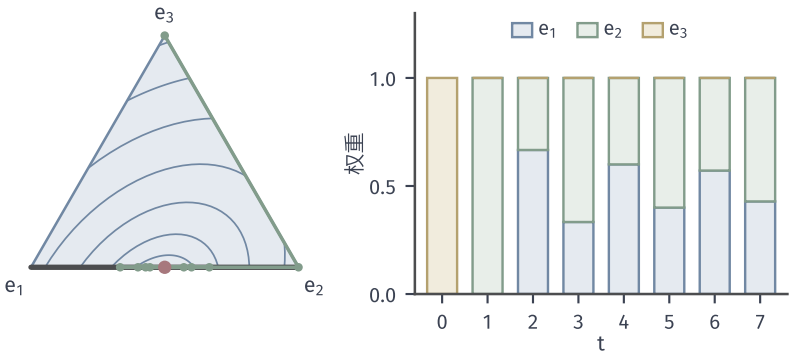


图 21.10　条件梯度法的路径与权重，$\alpha^{(t)}=2/(t+2)$，从顶点 $\boldsymbol{e}_3$ 出发。(a) 绿色路径先跳到 $\boldsymbol{e}_2$，然后沿活动边在解（红点）两侧摆动。(b) 前 8 个迭代点在三个顶点上的权重，第 t 根柱子的三段高度是 $\boldsymbol{x}^{(t)}$ 的三个坐标。

21.3.2 步长与可行性

式 (21.17)中的 $\alpha^{(t)}$ 可以怎样选，不同选法各用到什么信息？

三种规则　记方向 $\boldsymbol{d}^{(t)}=\boldsymbol{s}^{(t)}-\boldsymbol{x}^{(t)}$，用

$$\Gamma^{(t)}=\langle \boldsymbol{g}^{(t)},\boldsymbol{x}^{(t)}-\boldsymbol{s}^{(t)}\rangle \geq 0 \tag{21.21}$$

表示线性模型沿整条线段预测的下降量。三种规则如下。

- **预定序列**。用式 (21.20)，不需要函数值，也不需要 L。
- **线搜索**。$\alpha^{(t)}\in\arg\min_{\alpha\in[0,1]} f(\boldsymbol{x}^{(t)}+\alpha\boldsymbol{d}^{(t)})$，把范围限制在 $[0,1]$ 是为了留在线段上。
- **光滑上界**。最小化下降引理的上界，在 $[0,1]$ 上截断：

$$\alpha^{(t)}=\min\Big\{1,\ \frac{\Gamma^{(t)}}{L\|\boldsymbol{d}^{(t)}\|_2^2}\Big\}. \tag{21.22}$$

三种规则都使 $\alpha^{(t)}\in[0,1]$。预定序列在 $t\geq 0$ 时取值从 1 递减。线搜索按定义在区间内。光滑上界的分子非负，分母为正（若分母为零，则 $\boldsymbol{s}^{(t)}=\boldsymbol{x}^{(t)}$，已不必移动），再用 min 截断。

在预算例的第一轮比较这三种规则。方向是 $\boldsymbol{e}_2-\boldsymbol{e}_3=(0,1,-1)$，需要的几个量是

$$\Gamma^{(0)}=4.5,\qquad \|\boldsymbol{d}\|_2^2=2,\qquad \boldsymbol{d}^{\top}\boldsymbol{H}\boldsymbol{d}=6.$$

二次目标上的精确线搜索是 $\Gamma/(\boldsymbol{d}^{\mathsf{T}}\boldsymbol{H}\boldsymbol{d})$，所以

$$\alpha_{\text{预定}} = 1, \qquad \alpha_{\text{线搜索}} = \frac{3}{4}, \qquad \alpha_{\text{上界}} = \frac{9}{16}.$$

对应的目标值分别是 0.78125、0.59375 和 0.69922，图 21.11(a) 把这三点标在沿线段的目标曲线上。

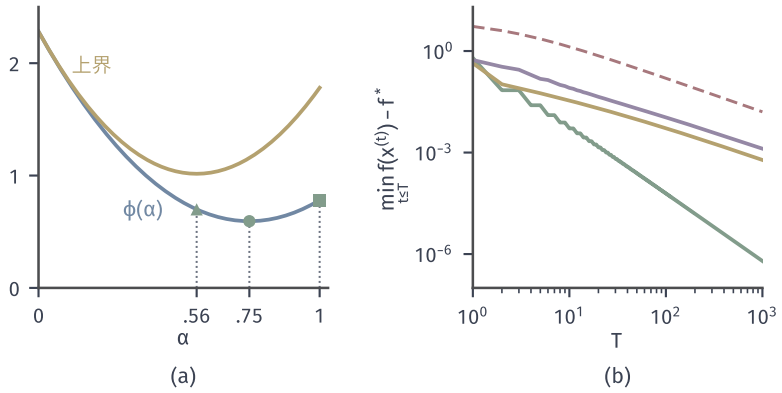


图 21.11 组合系数的三种选法。(a) 蓝线是从 $\boldsymbol{e}_3$ 到 $\boldsymbol{e}_2$ 的线段上的目标 $\phi(\alpha)$，黄线是光滑上界，三角、圆点、方块分别是光滑上界、线搜索、预定序列对应的系数。(b) 迄今最小目标差：绿线是预定序列，黄线是线搜索，紫线是光滑上界，红色虚线是定理 21.6的上界 $16/(T+2)$。

有限步界 下面证明目标差的上界，同时把线性子问题解得不准的情形放进去。设 $\boldsymbol{C}$ 的直径是 D，即集合中两点欧氏距离的最大值。证明要用到下一小节将要单独研究的一个事实，这里先在证明中直接用凸性得到。

定理 21.6 条件梯度法的有限步界 设 $\boldsymbol{C}$ 非空紧凸，直径为 D，f 在包含 $\boldsymbol{C}$ 的开集上可微，在 $\boldsymbol{C}$ 上凸且 L 光滑，$\delta \ge 0$。设线性子问题的解 $\tilde{\boldsymbol{s}}^{(t)} \in \boldsymbol{C}$ 满足

$$\langle \boldsymbol{g}^{(t)}, \tilde{\boldsymbol{s}}^{(t)} \rangle \le \min_{\boldsymbol{s}\in\boldsymbol{C}} \langle \boldsymbol{g}^{(t)}, \boldsymbol{s} \rangle + \frac{\delta}{2}\alpha^{(t)} L D^2, \tag{21.23}$$

并取 $\alpha^{(t)} = 2/(t+2)$。则对 $T \ge 1$，

$$f(\boldsymbol{x}^{(T)}) - f^\star \le \frac{2(1+\delta)LD^2}{T+2}. \tag{21.24}$$

证明 记 $e_t = f(\boldsymbol{x}^{(t)}) - f^\star$，$\alpha = \alpha^{(t)}$，$\boldsymbol{s}^*$ 是线性子问题的精确解。由下降引理，并用直径 D 放大移动的长度，得到

$$e_{t+1} \le e_t + \alpha \langle \boldsymbol{g}^{(t)}, \tilde{\boldsymbol{s}}^{(t)} - \boldsymbol{x}^{(t)} \rangle + \frac{L\alpha^2 D^2}{2}.$$

由式 (21.23)，把内积中的 $\tilde{\boldsymbol{s}}^{(t)}$ 换成 $\boldsymbol{s}^*$：

$$e_{t+1} \le e_t + \alpha \langle \boldsymbol{g}^{(t)}, \boldsymbol{s}^* - \boldsymbol{x}^{(t)} \rangle + \frac{(1+\delta) L\alpha^2 D^2}{2}.$$

由凸性，切平面在解处不高于目标，再由 $\boldsymbol{s}^*$ 在线性模型上最优，得到

$$\langle \boldsymbol{g}^{(t)}, \boldsymbol{s}^* - \boldsymbol{x}^{(t)} \rangle \le \langle \boldsymbol{g}^{(t)}, \boldsymbol{x}^\star - \boldsymbol{x}^{(t)} \rangle \le -e_t.$$

记 $K = (1+\delta) L D^2$，于是得到递推

$$e_{t+1} \le (1 - \alpha^{(t)}) e_t + \frac{K (\alpha^{(t)})^2}{2}.$$

下面对 T 归纳证明 $e_T \le 2K/(T+2)$。$t = 0$ 时 $\alpha^{(0)} = 1$，递推给出 $e_1 \le K/2 \le 2K/3$。设 $e_t \le 2K/(t+2)$，$t \ge 1$，代入 $\alpha^{(t)} = 2/(t+2)$：

$$e_{t+1} \le \frac{t}{t+2} \cdot \frac{2K}{t+2} + \frac{2K}{(t+2)^2} = \frac{2K(t+1)}{(t+2)^2}.$$

由 $(t+1)(t+3) \le (t+2)^2$，右端不超过 $2K/(t+3)$，归纳完成。 ■

δ 的作用是把内层误差与外层步长联系起来：式 (21.23)允许的误差随 $\alpha^{(t)}$ 减小，也就是越到后面线性子问题要解得越准。如果误差固定不变，递推中多出常数项 $\alpha^{(t)}\varepsilon$，目标差最终停在 ε 的量级。

线搜索和光滑上界的步长满足同样的上界。两者的新点都不高于在 $\alpha = 2/(t+2)$ 处的上界值，所以 $\delta = 0$ 时递推不变。第一轮的比较也说明，线搜索每步下降最多，并不代表后面的路径更好：图 21.11(b) 中，预定序列在这个例子上反而最快，第 21.3.4节解释其中的原因。

预算例中 $D^2 = 2$，$L = 4$，界 (21.24)是 $16/(T+2)$，$T = 100$ 时约为 0.157，实际目标差约 6×10^{-5}。这个界对所有满足条件的问题都成立，所以偏于保守。线搜索的黄线大致按 $1/T$ 下降：解在多面体的边上而不是顶点时，线搜索版本的目标差一般不能比 $1/T$ 快多少，证明需要构造性的下界分析，篇幅较长，读者可查阅 Frank–Wolfe 方法收敛下界的专门文献。预定序列的绿线约按 $1/T^2$ 下降，这来自两个顶点在解的两侧交替抵消的特殊结构，定理并不提供这样的保证。

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.3 条件梯度法（Frank–Wolfe）
21.3.1 线性子问题
21.3.2 步长与可行性
21.3.3 Frank–Wolfe 间隙
21.3.4 活跃顶点的调整（补充）
21.4 镜像下降
21.5 广义约化梯度法（GRG）
21.6 方法比较
21.7 本章小结

21.3.3 Frank–Wolfe 间隙

投影梯度用残差判断停止。条件梯度能不能在不知道 $f^\star$ 的情况下，判断离最优还有多远？线性子问题已经算出了答案。

定义与上界 式 (21.21)的量可以对任意可行点定义。

定义 21.7 Frank–Wolfe 间隙 设 $\boldsymbol{C}$ 非空紧凸，f 在 $\boldsymbol{x}\in\boldsymbol{C}$ 处可微，称

$$\Gamma(\boldsymbol{x})=\max_{\boldsymbol{s}\in\boldsymbol{C}}\langle\nabla f(\boldsymbol{x}),\boldsymbol{x}-\boldsymbol{s}\rangle \tag{21.25}$$

为Frank–Wolfe 间隙（Frank–Wolfe gap）。

取 $\boldsymbol{s}=\boldsymbol{x}$ 可知 $\Gamma(\boldsymbol{x})\geq 0$。它的值就是线性子问题的副产品，不需要额外计算：式 (21.21)的 $\Gamma^{(t)}$ 正是 $\Gamma(\boldsymbol{x}^{(t)})$。

这里没有沿用字母 g，因为 $\boldsymbol{g}^{(t)}$ 已经表示梯度。

定理 21.8 间隙上界目标差 在定义 21.7的条件下，$\Gamma(\boldsymbol{x})=0$ 当且仅当 $\boldsymbol{x}$ 满足变分不等式 (21.11)。若 f 在 $\boldsymbol{C}$ 上凸，则

$$f(\boldsymbol{x})-\min_{\boldsymbol{C}} f\leq\Gamma(\boldsymbol{x}). \tag{21.26}$$

证明 由式 (21.25)，$\Gamma(\boldsymbol{x})=0$ 就是对所有 $\boldsymbol{s}\in\boldsymbol{C}$，$\langle\nabla f(\boldsymbol{x}),\boldsymbol{x}-\boldsymbol{s}\rangle\leq 0$，这正是式 (21.11)。

设 $\boldsymbol{x}^\star$ 是最优解，它存在，因为 $\boldsymbol{C}$ 紧、f 连续。由凸性和 Γ 的定义，

$$f(\boldsymbol{x})-f(\boldsymbol{x}^\star)\leq\langle\nabla f(\boldsymbol{x}),\boldsymbol{x}-\boldsymbol{x}^\star\rangle\leq\Gamma(\boldsymbol{x}).$$

■

图 21.12(a) 在一元情形说明这个不等式。切线在集合上的最低值位于端点 $\boldsymbol{s}$，凸函数高于切线，所以最优值高于切线的最低值。切线在当前点的高度是 $f(\boldsymbol{x})$，Γ 就是这段高度差。这和第 18章用下界判断最优的思路相同，线性化给出了一个可计算的下界

$$f(\boldsymbol{x})-\Gamma(\boldsymbol{x})\leq f^\star.$$

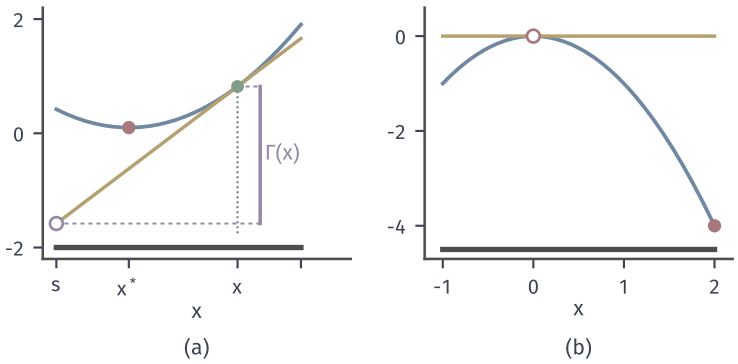


图 21.12 间隙的几何。深灰线是可行区间，蓝线是目标，黄线是当前点的切线。(a) 凸目标 $f(x)=x^2/2+0.1$，$\boldsymbol{C}=[-0.8,1.9]$，$x=1.2$：切线在空心紫点处达到区间上的最低值，紫色线段的长度是 $\Gamma(x)$，它不小于 $f(x)-f^\star$。(b) 非凸目标 $-x^2$，$\boldsymbol{C}=[-1,2]$：局部极大点 $x=0$ 处切线水平，$\Gamma=0$，而全局最优解在 2。

预算例中 $\boldsymbol{x}^{(3)}=(\frac{1}{3},\frac{2}{3},0)$，梯度 $(-\frac{2}{3},\frac{1}{6},0)$，最小分量是 $-\frac{2}{3}$，内积 $\langle \boldsymbol{g},\boldsymbol{x}\rangle=-\frac{1}{9}$，于是

$$\Gamma(\boldsymbol{x}^{(3)})=-\frac{1}{9}+\frac{2}{3}=\frac{5}{9}\approx 0.556.$$

真实目标差约为 0.0694，不超过间隙。这说明了间隙的特点：可靠但往往偏大。图 21.13(a) 的两条曲线一直保持这种上下关系。

用间隙做停止检验时，可以在每轮计算 $\Gamma^{(t)}$，当它不超过容差时输出。把这一步放进第 21.3.1节的每轮更新，就得到完整的算法。

非凸目标 式 (21.26)要用凸性。目标非凸时，$\Gamma=0$ 只表示一阶驻定，图 21.12(b) 的局部极大点就是例子。

不过间隙仍能作为进展的度量。取式 (21.22)的步长，把 $\|\boldsymbol{d}\|_2$ 放大为 D，当 $\Gamma\le LD^2$ 时一步至少下降 $\Gamma^2/(2LD^2)$，否则至少下降 $\Gamma/2$。把这些下降量累加，并用 $\Delta=f(\boldsymbol{x}^{(0)})-\inf_{\boldsymbol{C}} f$ 作为总额，得到

$$\min_{0\le t<T}\Gamma(\boldsymbol{x}^{(t)})\le \max\Big\{\sqrt{\frac{2LD^2\Delta}{T}},\ \frac{2\Delta}{T}\Big\}. \tag{21.27}$$

所以驻定度量以 $1/\sqrt{T}$ 的速度减小，和投影残差 (21.13)开方之后的阶相同。

近似子问题的停止界 当线性子问题只能近似求解时，设已知误差上界 ε：

$$\langle \boldsymbol{g},\tilde{\boldsymbol{s}}\rangle\le \min_{\boldsymbol{s}\in\boldsymbol{C}}\langle \boldsymbol{g},\boldsymbol{s}\rangle+\varepsilon.$$

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.3 条件梯度法（Frank–Wolfe）
21.3.1 线性子问题
21.3.2 步长与可行性
21.3.3 Frank–Wolfe 间隙
21.3.4 活跃顶点的调整（补充）
21.4 镜像下降
21.5 广义约化梯度法（GRG）
21.6 方法比较
21.7 本章小结

用近似解算出来的量记作

$$\tilde{\Gamma} = \langle \boldsymbol{g}, \boldsymbol{x} - \tilde{\boldsymbol{s}} \rangle,$$

它比真实间隙小。把定义和误差条件代入，得到

$$\tilde{\Gamma} \le \Gamma(\boldsymbol{x}) \le \tilde{\Gamma} + \varepsilon. \tag{21.28}$$

$\tilde{\Gamma}$ 是真实间隙的下界，单用它停止可能过早。可靠的停止量是 $\tilde{\Gamma} + \varepsilon$，所以必须知道内层求解误差的上界。图 21.13(b) 让内层在最优顶点与次优顶点相差不超过 $\varepsilon = 0.1$ 时返回次优顶点，算出的 $\tilde{\Gamma}$ 甚至可以是负数，而真实间隙一直夹在 $\tilde{\Gamma}$ 与 $\tilde{\Gamma} + \varepsilon$ 之间。

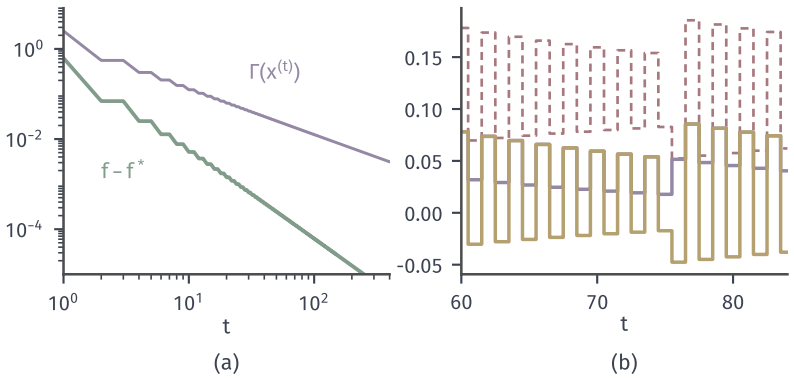


图 21.13 间隙作为证书，预算例，$\alpha^{(t)} = 2/(t+2)$。(a) 紫线是 $\Gamma(\boldsymbol{x}^{(t)})$，绿线是目标差，前者始终在上方。(b) 第 60 至 84 轮，内层返回次优顶点时：黄线是算出的 $\tilde{\Gamma}$，紫线是真实间隙 Γ，红色虚线是 $\tilde{\Gamma} + \varepsilon$，$\varepsilon = 0.1$。

21.3.4 活跃顶点的调整（补充）

本小节是补充内容。第 21.3.1节留下一个问题：旧顶点的权重只能等比例缩小。如果最优解不用某个顶点，这个顶点的权重永远消不掉，该怎么办？

之字形现象 用精确线搜索从 $\boldsymbol{e}_3$ 出发，第一步 $\alpha = \frac{3}{4}$，得到 $(0, \frac{3}{4}, \frac{1}{4})$。第二步 $\alpha = \frac{4}{9}$，得到 $(\frac{4}{9}, \frac{5}{12}, \frac{5}{36})$。

$\boldsymbol{e}_3$ 的权重每步只乘以 $1 - \alpha^{(t)}$，线搜索的 $\alpha^{(t)}$ 逐渐变小，第 1000 步第三个坐标仍约为 1.2×10^{-3}。图 21.14(a) 显示，路径在底边上方反复横跳，既要减小 x_3，又要调整 x_1, x_2。这也解释了图 21.11(b)：预定序列的第一步 $\alpha^{(0)} = 1$ 恰好把 $\boldsymbol{e}_3$ 清零，这个好处只因为起点恰好是要丢弃的顶点，一般问题上不能指望。

远离步 既然能朝好的顶点走，也应该能从坏的顶点离开。把 $\boldsymbol{x}$ 写成活跃顶点集 $\boldsymbol{S}$ 上的凸组合，权重 $w_{\boldsymbol{v}} > 0$。**远离步**（away step）选出活跃顶点中线性模型最差的一个，沿着背离它的方向走：

$$\boldsymbol{v}^{(t)} \in \arg\max_{\boldsymbol{v} \in \boldsymbol{S}} \langle \boldsymbol{g}^{(t)}, \boldsymbol{v} \rangle, \qquad \boldsymbol{d} = \boldsymbol{x}^{(t)} - \boldsymbol{v}^{(t)}. \tag{21.29}$$

新点是 $\boldsymbol{x} + \gamma \boldsymbol{d}$，各权重变成 $(1+\gamma) w_{\boldsymbol{u}}$，而 $\boldsymbol{v}^{(t)}$ 的权重变成 $(1+\gamma) w_{\boldsymbol{v}} - \gamma$。它必须非负，这给出步长上限

$$\gamma \le \gamma_{\max} = \frac{w_{\boldsymbol{v}}}{1 - w_{\boldsymbol{v}}}.$$

当 $\boldsymbol{S}$ 只有一个顶点时 $w_{\boldsymbol{v}} = 1$，$\gamma_{\max}$ 无定义，这时不存在远离方向，只走普通的 Frank–Wolfe 步。取到 $\gamma = \gamma_{\max}$ 时该顶点的权重正好变成零，从活跃集中删除，这称为丢弃步。

成对更新 另一种做法是把权重直接从最差的活跃顶点搬到最好的顶点。**成对步**（pairwise step）取方向 $\boldsymbol{d} = \boldsymbol{s}^{(t)} - \boldsymbol{v}^{(t)}$，权重更新是

$$w_{\boldsymbol{s}} \leftarrow w_{\boldsymbol{s}} + \gamma, \qquad w_{\boldsymbol{v}} \leftarrow w_{\boldsymbol{v}} - \gamma, \qquad 0 \le \gamma \le w_{\boldsymbol{v}}.$$

其他权重不变，所有权重非负、和为一，所以新点仍是可行的凸组合。

用预算例走一遍，每步用精确线搜索并在上限处截断。第一步只有 $\boldsymbol{e}_3$ 活跃，$\boldsymbol{s} = \boldsymbol{e}_2$，$\gamma = \tfrac{3}{4}$，到达 $(0, \tfrac{3}{4}, \tfrac{1}{4})$。

第二步 $\boldsymbol{g} = (-1, \tfrac{1}{2}, \tfrac{1}{2})$，$\boldsymbol{s} = \boldsymbol{e}_1$，$\boldsymbol{e}_2, \boldsymbol{e}_3$ 并列最差，取 $\boldsymbol{v} = \boldsymbol{e}_3$。方向 $\boldsymbol{d} = (1, 0, -1)$，精确步长是 $1.5/3 = \tfrac{1}{2}$，超过上限 $w_{\boldsymbol{e}_3} = \tfrac{1}{4}$，于是截断成丢弃步：

$$\boldsymbol{x} = \left(\tfrac{1}{4}, \tfrac{3}{4}, 0\right).$$

第三步 $\boldsymbol{g} = (-\tfrac{3}{4}, \tfrac{1}{2}, 0)$，$\boldsymbol{s} = \boldsymbol{e}_1$，$\boldsymbol{v} = \boldsymbol{e}_2$，方向 $(1, -1, 0)$，精确步长 $\tfrac{5/4}{5} = \tfrac{1}{4}$，得到

$$\boldsymbol{x} = \left(\tfrac{1}{2}, \tfrac{1}{2}, 0\right).$$

三步到达最优解，此时 $\Gamma = 0$。图 21.14对比了这两条路径。

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.3 条件梯度法（Frank–Wolfe）
21.4 镜像下降
21.4.1 Bregman 距离
21.4.2 镜像更新
21.4.3 熵势与指数更新
21.4.4 进展与输出
21.5 广义约化梯度法（GRG）
21.6 方法比较
21.7 本章小结

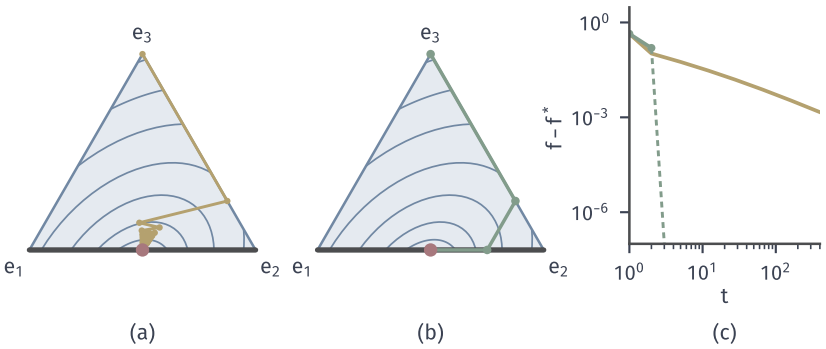


图 21.14 基本流程与成对更新，都用精确线搜索，从 $\boldsymbol{e}_3$ 出发。(a) 黄色路径是基本的条件梯度法，前 25 步在解上方横跳。(b) 绿色路径是成对更新，第二步把 $\boldsymbol{e}_3$ 的权重清零，第三步到达解。(c) 目标差：黄线是基本流程，绿线是成对更新，第三步目标差为零，虚线表示落到坐标轴下方。

这个三维例子里，到达活动边后问题变成一维二次函数，线搜索一步到位，所以结果格外干净。不能由此推出删除顶点就有线性收敛。这类变体的线性收敛结论依赖目标的曲率、多面体的几何常数（描述顶点相对于面的“尖锐”程度），并要单独计数那些权重被顶到零的步，证明篇幅较长，读者可查阅关于 Frank–Wolfe 变体线性收敛的专门论文。此外，这些方法要保存活跃顶点及其权重，存储和维护的代价随活跃集增长。

21.4 镜像下降

在预算例中，把第三个项目的份额从 0.01 变到 0.02 和从 0.50 变到 0.51，欧氏距离相同。可是前者把这个项目的份额翻了一倍，后者几乎没有变化。对比例这样的量，有没有一把更合适的尺子？本节回答这个问题：把投影梯度中的欧氏距离换成由凸势函数决定的代价，然后在单纯形上算出具体的公式。

21.4.1 Bregman 距离

欧氏距离的平方可以看成是 $\frac{1}{2}\|\boldsymbol{x}\|_2^2$ 这个碗与它的切平面之间的高度差。换一只碗，就换了一把尺子。

定义 设 h 是凸函数，在点 $\boldsymbol{x}$ 可微。把 h 在 $\boldsymbol{x}$ 处的切平面延伸到 $\boldsymbol{u}$，势函数实际值高出切平面的量就是我们要的代价。

定义 21.9 Bregman 距离 设 h 是凸函数，在 $\boldsymbol{x}$ 处可微，$\boldsymbol{u} \in \operatorname{dom} h$。称

$$D_h(\boldsymbol{u}, \boldsymbol{x}) = h(\boldsymbol{u}) - h(\boldsymbol{x}) - \langle \nabla h(\boldsymbol{x}), \boldsymbol{u} - \boldsymbol{x} \rangle \tag{21.30}$$

为势函数h 生成的Bregman 距离（Bregman distance）。

本节的 h 是势函数，与等式约束无关。由凸性，切平面不高于 h，所以 $D_h(\boldsymbol{u}, \boldsymbol{x}) \geq 0$；若 h 严格凸，等号只在 $\boldsymbol{u} = \boldsymbol{x}$ 时成立。

取 $h(\boldsymbol{x}) = \frac{1}{2}\|\boldsymbol{x}\|_2^2$，代入式 (21.30)，得到

$$D_h(\boldsymbol{u}, \boldsymbol{x}) = \tfrac{1}{2}\|\boldsymbol{u}\|_2^2 - \tfrac{1}{2}\|\boldsymbol{x}\|_2^2 - \langle \boldsymbol{x}, \boldsymbol{u} - \boldsymbol{x} \rangle = \tfrac{1}{2}\|\boldsymbol{u} - \boldsymbol{x}\|_2^2.$$

这时恰好是欧氏距离平方的一半。

不是真正的距离 名字里虽有“距离”，D_h 通常不对称，也不满足三角不等式。图 21.15对比了两种势函数：抛物线上两条竖线段长度相等，$x \ln x$ 的曲线上两条竖线段长度不同。

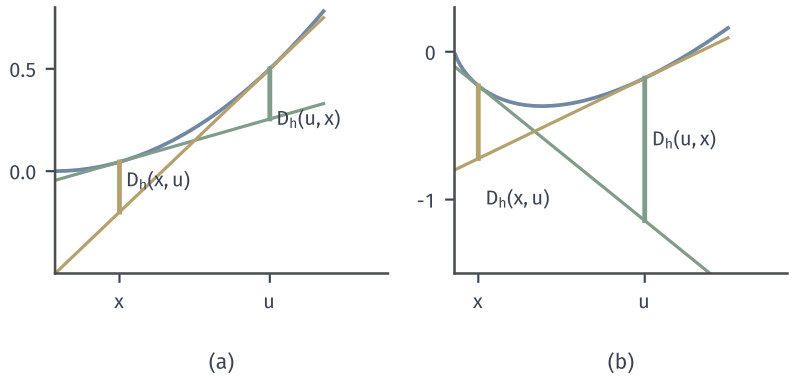


图 21.15 Bregman 距离是势函数高出切线的量。蓝线是势函数，绿线和黄线分别是 x 和 u 处的切线，同色竖线段分别是 $D_h(u, x)$ 和 $D_h(x, u)$。(a)$h(t) = t^2/2$，两段等长。(b)$h(t) = t \ln t$，$x = 0.1$，$u = 0.8$，两段不等长。

用一个可手算的例子来看。取 $h(\boldsymbol{x}) = \sum_i x_i \ln x_i$ 和两个坐标和为一的点

$$\boldsymbol{u} = (0.5, 0.5), \qquad \boldsymbol{x} = (0.2, 0.8).$$

这时 $D_h(\boldsymbol{u}, \boldsymbol{x})$ 就是 $\sum_i u_i \ln(u_i/x_i)$，推导见第 21.4.3节。代入两种顺序，得到

$$D_h(\boldsymbol{u}, \boldsymbol{x}) \approx 0.2231, \qquad D_h(\boldsymbol{x}, \boldsymbol{u}) \approx 0.1927.$$

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.3 条件梯度法（Frank–Wolfe）
21.4 镜像下降
21.4.1 Bregman 距离
21.4.2 镜像更新
21.4.3 熵势与指数更新
21.4.4 进展与输出
21.5 广义约化梯度法（GRG）
21.6 方法比较
21.7 本章小结

分析所需的条件 把 D_h 用到算法里，有三件事要先核对。第一，$\nabla h(\boldsymbol{x})$ 必须存在，所以展开点要在 h 的可微区域内，对熵势就是相对内部。第二，要控制变量移动的大小，需要 h 在某个范数下强凸，也就是 D_h 能从下方控制这个范数的平方。第三，子问题要有解，这要看定义域与集合是否匹配。

图 21.16比较了这把尺子的“单位球”。在三角形中央，熵势的球接近圆。靠近边界时，球在朝边界的方向被压扁：同样的代价只能让小坐标做很小的绝对变化。

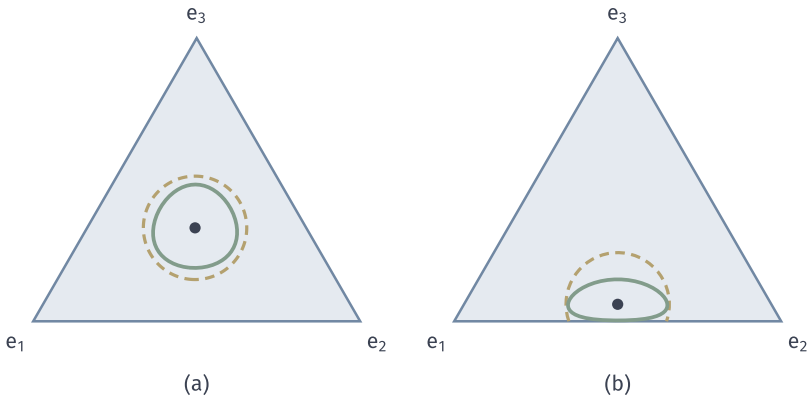


图 21.16 同一单纯形上两把尺子的等距线。绿色实线是熵势的 $\{\boldsymbol{u} : D_h(\boldsymbol{u},\boldsymbol{c}) = 0.05\}$，黄色虚线是欧氏圆 $\{\boldsymbol{u} : \frac{1}{2}\|\boldsymbol{u}-\boldsymbol{c}\|_2^2 = 0.025\}$，黑点是中心 $\boldsymbol{c}$。(a)$\boldsymbol{c} \approx (1/3, 1/3, 1/3)$。(b)$\boldsymbol{c} = (0.47, 0.47, 0.06)$，靠近底边，绿色曲线在朝边的一侧被压扁，黄色圆已越出三角形。

21.4.2 镜像更新

有了新尺子，更新公式是什么？它又如何退回熟悉的投影梯度？

主要思想 投影梯度在 $\boldsymbol{C}$ 上最小化线性模型加欧氏距离。把欧氏距离换成 D_h，就得到**镜像下降法**（mirror descent）[2]：

$$\boldsymbol{x}^{(t+1)} \in \arg\min_{\boldsymbol{x}\in\boldsymbol{C}} \left\{ \alpha^{(t)} \langle \boldsymbol{g}^{(t)}, \boldsymbol{x} \rangle + D_h(\boldsymbol{x}, \boldsymbol{x}^{(t)}) \right\}. \tag{21.31}$$

这里 $\boldsymbol{g}^{(t)}$ 可以是当前梯度，也可以是目标非光滑时所选的一个凸次梯度。次梯度的定义见第 11章。

D_h 的作用相当于一根弹簧，把新点拉住，不让它离当前点太远。不同的是，这根弹簧的松紧随位置变化。

[2] A. Beck, M. Teboulle, *Mirror Descent and Nonlinear Projected Subgradient Methods for Convex Optimization* In Operations Research Letters, 2003, vol. 31, no. 3, pp. 167–175

完整的计算 式 (21.31)可以拆成三步。设 $\boldsymbol{C}$ 在 h 的可微区域内，先对 $\boldsymbol{x}$ 求驻点。$D_h(\boldsymbol{x}, \boldsymbol{x}^{(t)})$ 关于 $\boldsymbol{x}$ 的梯度是 $\nabla h(\boldsymbol{x}) - \nabla h(\boldsymbol{x}^{(t)})$，于是无约束时的驻点 $\boldsymbol{w}$ 满足

$$\nabla h(\boldsymbol{w}) = \nabla h(\boldsymbol{x}^{(t)}) - \alpha^{(t)} \boldsymbol{g}^{(t)}. \tag{21.32}$$

这说明梯度步不是在变量本身上走，而是在 ∇h 的值上走。第一步，用 ∇h 把 $\boldsymbol{x}^{(t)}$ 映到梯度空间。第二步，在那里减去 $\alpha^{(t)}\boldsymbol{g}^{(t)}$。第三步，用 ∇h 的逆映射取回变量空间，得到 $\boldsymbol{w}$。

$\boldsymbol{w}$ 可能不在 $\boldsymbol{C}$ 中。把式 (21.31)的目标用式 (21.32)改写，常数项不影响最小点，于是

$$\boldsymbol{x}^{(t+1)} = \arg\min_{\boldsymbol{x} \in \boldsymbol{C}} D_h(\boldsymbol{x}, \boldsymbol{w}).$$

这是按 D_h 度量的投影。图 21.17把这个往返过程画了出来，“镜像”这个名字指的就是 ∇h 在两个空间之间的来回映射。

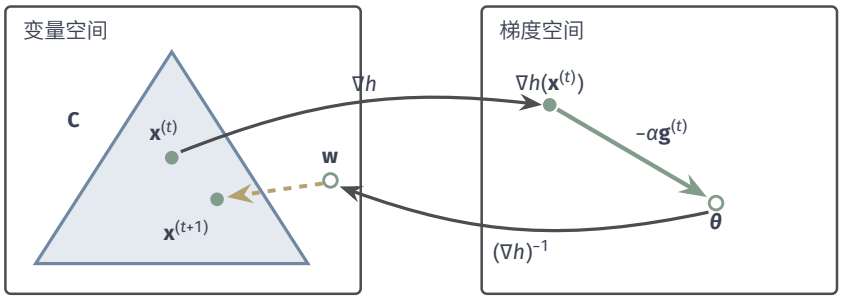


图 21.17 镜像更新的结构。∇h 把当前点送到梯度空间，绿色箭头在那里减去 $\alpha\boldsymbol{g}^{(t)}$，逆映射把结果带回变量空间得到 $\boldsymbol{w}$，黄色虚线按 D_h 投影回集合 $\boldsymbol{C}$ 得到 $\boldsymbol{x}^{(t+1)}$。

取 $h = \frac{1}{2}\|\cdot\|_2^2$，$\nabla h$ 是恒等映射，式 (21.32)给出 $\boldsymbol{w} = \boldsymbol{x}^{(t)} - \alpha^{(t)}\boldsymbol{g}^{(t)}$，再做欧氏投影，正是式 (21.4)。所以投影梯度是镜像下降的特例。

其他势函数要核对的事 换一个势函数，要分别回答三个问题。解是否存在：若 $\boldsymbol{C}$ 紧、h 连续，子问题有解；否则要检查水平集。解是否唯一：h 严格凸时唯一。下一步能否继续：$\boldsymbol{x}^{(t+1)}$ 必须落在 h 的可微区域内，否则 $\nabla h(\boldsymbol{x}^{(t+1)})$ 不存在，式 (21.30)无法展开。

第三个问题最容易被忽略。以一元势函数 $h(x) = x^{3/2}$（定义域 $x \geq 0$）为例，导数 $\frac{3}{2}\sqrt{x}$ 在边界保持有限，梯度为正且步长足够大时，子问题的解就落在 $x = 0$ 上。这个点在定义域的边界，h 作为定义域外取 $+\infty$ 的函数在此处不可微。熵势不会发生这种事：它的导数在边界趋于 $-\infty$，下一小节会看到迭代被挡在内部。

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.3 条件梯度法（Frank–Wolfe）
21.4 镜像下降
21.4.1 Bregman 距离
21.4.2 镜像更新
21.4.3 熵势与指数更新
21.4.4 进展与输出
21.5 广义约化梯度法（GRG）
21.6 方法比较
21.7 本章小结

21.4.3 熵势与指数更新

单纯形上的比例变量适合用哪只碗？用**熵势**（entropic potential）可以把式 (21.31)解成闭式，并得到乘法形式的更新。

熵势 取

$$h(\boldsymbol{x}) = \sum_{i=1}^{n} x_i \ln x_i, \qquad \boldsymbol{x} \geq \mathbf{0}, \tag{21.33}$$

并按 $0 \ln 0 = 0$ 延拓到坐标为零的边界。h 在 $\boldsymbol{x} \geq \mathbf{0}$ 上连续，梯度 $\nabla h(\boldsymbol{x})_i = \ln x_i + 1$ 只在所有坐标为正时存在，所以展开点必须是正向量。

对坐标和都为一的 $\boldsymbol{u}$ 和正向量 $\boldsymbol{x}$，代入式 (21.30)，线性项中的 $\sum_i (u_i - x_i)$ 等于零，得到

$$D_h(\boldsymbol{u}, \boldsymbol{x}) = \sum_{i=1}^{n} u_i \ln \frac{u_i}{x_i}. \tag{21.34}$$

指数更新 在 $\boldsymbol{\Delta}$ 上解式 (21.31)。从正向量 $\boldsymbol{x}^{(t)}$ 出发，暂时忽略 $\boldsymbol{x} \geq \mathbf{0}$，只对等式约束引入乘子 ν，对 x_i 求偏导并令其为零：

$$\alpha g_i + \ln \frac{x_i}{x_i^{(t)}} + 1 + \nu = 0.$$

解出 x_i，常数因子 $\mathrm{e}^{-1-\nu}$ 对所有坐标相同，它由坐标和为一确定，于是

$$x_i^{(t+1)} = \frac{x_i^{(t)} \exp\!\left(-\alpha g_i\right)}{\sum_{j=1}^{n} x_j^{(t)} \exp\!\left(-\alpha g_j\right)}. \tag{21.35}$$

结果每个坐标严格为正，所以被忽略的约束 $\boldsymbol{x} \geq \mathbf{0}$ 确实不活跃，上面的驻点是原子问题的解（目标严格凸，驻点唯一）。下一步的展开点仍是正向量，迭代可以无限进行下去。这种**指数更新**（exponentiated update）是乘法的：梯度小的坐标放大，梯度大的坐标缩小，最后归一化。

两个坐标的比较 设只有两个坐标，$\boldsymbol{x} = (0.9, 0.1)$，$\boldsymbol{g} = (0, 1)$，$\alpha = \tfrac{1}{2}$。投影梯度的梯度步终点是 $(0.9, -0.4)$，投影到线段上得到

$$\boldsymbol{x}^{+}_{\text{投影}} = (1, 0).$$

指数更新先算 $(0.9,\ 0.1\mathrm{e}^{-1/2}) = (0.9,\ 0.06065)$，归一化得

$$\boldsymbol{x}^{+}_{\text{镜像}} \approx (0.9369, 0.0631).$$

投影梯度一步把第二个坐标截到零，镜像更新只把它减小了约 37%。

两者的差别随坐标大小变化。两个坐标时投影更新是 $x_2^+ = \max\{x_2 - \frac{1}{2}\alpha(g_2 - g_1), 0\}$，变化量与 x_2 本身无关；镜像更新是乘以一个因子。图 21.18显示：$x_2 = 0.5$ 时两者起步斜率相同；$x_2 = 0.05$ 时投影很快归零，镜像更新则按比例缓慢减小。

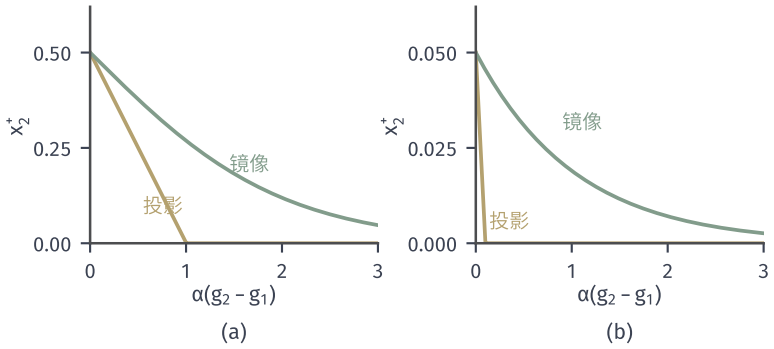


图 21.18　两个坐标的一步更新，横轴是梯度差乘步长，纵轴是新的 x_2。黄线是投影更新，绿线是指数更新。(a)$x_2 = 0.5$，x_2 较大时两者在起点相切。(b)$x_2 = 0.05$，投影在横轴 0.1 处归零，指数更新缓慢衰减。

变量

- $\boldsymbol{x}^{(t)} \in \boldsymbol{\Delta}$：当前点，所有坐标为正。
- $\boldsymbol{g}^{(t)}$：当前梯度或所选次梯度。
- $\boldsymbol{w}^{(t)} \in \mathbb{R}^n$：归一化前的正向量。
- $\alpha > 0$：步长；T：总步数。

初始化　取正向量起点，常用均匀分布。例中与投影梯度用同一起点 $\boldsymbol{x}^{(0)} = (0.1, 0.2, 0.7)$，步长 $\alpha = 1/4$，第 21.4.4节说明这个步长的来历。

每轮更新　在第 t 轮：

1. **计算指数因子**。每个坐标乘以指数因子，得到 $\boldsymbol{w}^{(t)}$。例中第一轮 $\boldsymbol{g}^{(0)} = (-0.9, -1.7, 1.4)$，于是

$$\boldsymbol{w}^{(0)} \approx (0.12523, 0.30592, 0.49328).$$

2. **归一化**。由式 (21.35)，把 $\boldsymbol{w}^{(t)}$ 除以坐标和得到 $\boldsymbol{x}^{(t+1)}$。例中第一轮分母约为 0.92443，于是

$$\boldsymbol{x}^{(1)} \approx (0.13547, 0.33093, 0.53361), \qquad f(\boldsymbol{x}^{(1)}) \approx 0.83140.$$

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.3 条件梯度法（Frank–Wolfe）
21.4 镜像下降
21.4.1 Bregman 距离
21.4.2 镜像更新
21.4.3 熵势与指数更新
21.4.4 进展与输出
21.5 广义约化梯度法（GRG）
21.6 方法比较
21.7 本章小结

例中第二轮 $\boldsymbol{g}^{(1)} \approx (-0.8645, -1.1763, 1.0672)$，分母约为 1.02087，于是

$$\boldsymbol{x}^{(2)} \approx (0.16472, 0.43499, 0.40030), \qquad f(\boldsymbol{x}^{(2)}) \approx 0.58130.$$

例中第三轮 $\boldsymbol{g}^{(2)} \approx (-0.8353, -0.7601, 0.8006)$，分母约为 1.05667，于是

$$\boldsymbol{x}^{(3)} \approx (0.19208, 0.49781, 0.31011), \qquad f(\boldsymbol{x}^{(3)}) \approx 0.45489.$$

运行到 $T = 60$，目标差约为 6.6×10^{-5}，第三个坐标始终为正。最终得到的 $\boldsymbol{x}^{(60)}$ 在 x_3 上还有约 1.3×10^{-4} 的残留量，它每轮大约乘以 0.88，但不会精确到零。

图 21.19将它和投影梯度比较。投影梯度在第 3 步把 x_3 截成零，之后活动集就固定了。镜像下降的路径光滑，x_3 每轮大约乘以同一个因子。这是一种取舍：投影能识别出活动约束，镜像更新保持稠密的正权重。

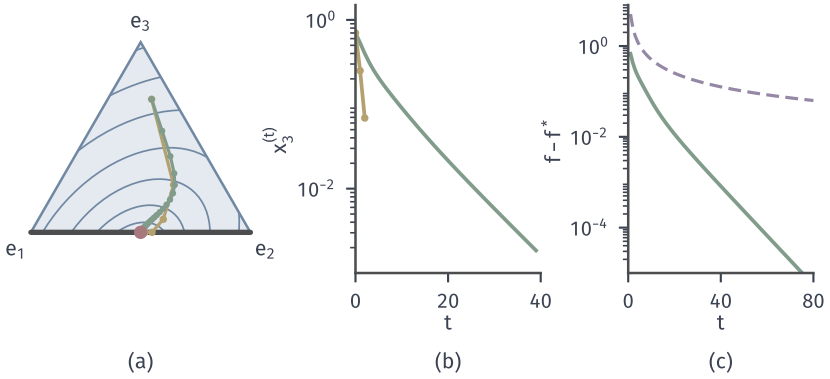


图 21.19　预算例上的镜像下降（绿）与投影梯度（黄），步长都是 1/4，起点 $(0.1, 0.2, 0.7)$。(a) 两条路径，镜像下降的路径弯曲着逼近底边。(b) 第三个坐标 $x_3^{(t)}$（对数轴）：投影梯度第 3 步起为零，从图中消失；镜像下降几何衰减。(c) 镜像下降的目标差（绿）与定理 21.12的上界 $LD_h(\boldsymbol{x}^\star, \boldsymbol{x}^{(0)})/T$（紫色虚线）。

21.4.4 进展与输出

镜像下降的一次更新到底带来了多少进展？目标是否一定下降？答案取决于手上有哪种假设。

三点关系　分析的工具是下面的引理，它把一次更新转成比较点到两个迭代点的 D_h 之差，求和时可以裂项。

引理 21.10　三点关系　设 $\boldsymbol{C}$ 闭凸，h 在开集 $\boldsymbol{U}$ 上可微且凸，$\boldsymbol{x} \in \boldsymbol{U}$，$\boldsymbol{x}^{+}$ 是式 (21.31)的解，并且 $\boldsymbol{x}^{+} \in \boldsymbol{U}$。则对所有 $\boldsymbol{u} \in \boldsymbol{C} \cap \operatorname{dom} h$，

$$\alpha\langle \boldsymbol{g}, \boldsymbol{x}^{+} - \boldsymbol{u} \rangle \le D_h(\boldsymbol{u}, \boldsymbol{x}) - D_h(\boldsymbol{u}, \boldsymbol{x}^{+}) - D_h(\boldsymbol{x}^{+}, \boldsymbol{x}). \tag{21.36}$$

证明　式 (21.31)是凸目标在凸集上的最小化，$\boldsymbol{x}^{+}$ 满足变分不等式：

$$\left\langle \alpha \boldsymbol{g} + \nabla h(\boldsymbol{x}^{+}) - \nabla h(\boldsymbol{x}),\ \boldsymbol{u} - \boldsymbol{x}^{+} \right\rangle \ge 0.$$

移项得到

$$\alpha\langle \boldsymbol{g}, \boldsymbol{x}^{+} - \boldsymbol{u} \rangle \le \left\langle \nabla h(\boldsymbol{x}^{+}) - \nabla h(\boldsymbol{x}),\ \boldsymbol{u} - \boldsymbol{x}^{+} \right\rangle.$$

把式 (21.30)的三个距离展开相减，$h(\boldsymbol{u})$、$h(\boldsymbol{x})$、$h(\boldsymbol{x}^{+})$ 都抵消，剩下的线性项正好是

$$D_h(\boldsymbol{u}, \boldsymbol{x}) - D_h(\boldsymbol{u}, \boldsymbol{x}^{+}) - D_h(\boldsymbol{x}^{+}, \boldsymbol{x}) = \left\langle \nabla h(\boldsymbol{x}^{+}) - \nabla h(\boldsymbol{x}),\ \boldsymbol{u} - \boldsymbol{x}^{+} \right\rangle.$$

代入上式即得结论。 ■

次梯度分析　第一种情形只假设次梯度有界，目标可以不光滑。设 $\|\cdot\|$ 是某个范数，它的对偶范数是

$$\|\boldsymbol{g}\|_{*} = \max_{\|\boldsymbol{v}\| \le 1} \langle \boldsymbol{g}, \boldsymbol{v} \rangle.$$

定理 21.11　镜像下降的平均点界　设 $\boldsymbol{C}$ 闭凸，f 在 $\boldsymbol{C}$ 上凸，$\boldsymbol{g}^{(t)}$ 是 f 在 $\boldsymbol{x}^{(t)}$ 处的次梯度，$\|\boldsymbol{g}^{(t)}\|_{*} \le G$。设各迭代点都在 h 的可微区域内，且在 $\boldsymbol{C}$ 上

$$D_h(\boldsymbol{u}, \boldsymbol{x}) \ge \frac{1}{2}\|\boldsymbol{u} - \boldsymbol{x}\|^2. \tag{21.37}$$

取固定步长 α，平均点 $\bar{\boldsymbol{x}} = \frac{1}{T}\sum_{t<T} \boldsymbol{x}^{(t)}$，则对 $\boldsymbol{u} \in \boldsymbol{C}$，

$$f(\bar{\boldsymbol{x}}) - f(\boldsymbol{u}) \le \frac{D_h(\boldsymbol{u}, \boldsymbol{x}^{(0)})}{\alpha T} + \frac{\alpha G^2}{2}. \tag{21.38}$$

证明 记 $\boldsymbol{x}=\boldsymbol{x}^{(t)}$，$\boldsymbol{x}^{+}=\boldsymbol{x}^{(t+1)}$，$\boldsymbol{g}=\boldsymbol{g}^{(t)}$。由次梯度不等式，把内积拆成两部分：

$$\alpha\big(f(\boldsymbol{x})-f(\boldsymbol{u})\big)\le \alpha\langle \boldsymbol{g},\boldsymbol{x}^{+}-\boldsymbol{u}\rangle+\alpha\langle \boldsymbol{g},\boldsymbol{x}-\boldsymbol{x}^{+}\rangle.$$

第二项用对偶范数和 Young 不等式放大，再用 D_h 的强凸下界：

$$\alpha\langle \boldsymbol{g},\boldsymbol{x}-\boldsymbol{x}^{+}\rangle\le \frac{\alpha^2 G^2}{2}+\frac{1}{2}\|\boldsymbol{x}-\boldsymbol{x}^{+}\|^2\le \frac{\alpha^2G^2}{2}+D_h(\boldsymbol{x}^{+},\boldsymbol{x}).$$

第一项用引理 21.10，$D_h(\boldsymbol{x}^{+},\boldsymbol{x})$ 恰好抵消，得到

$$\alpha\big(f(\boldsymbol{x}^{(t)})-f(\boldsymbol{u})\big)\le D_h(\boldsymbol{u},\boldsymbol{x}^{(t)})-D_h(\boldsymbol{u},\boldsymbol{x}^{(t+1)})+\frac{\alpha^2G^2}{2}.$$

对 $t=0,\dots,T-1$ 求和，右端裂项，丢掉未项 $D_h\ge 0$。两边除以 αT，再用 f 的凸性把平均值换成 $f(\bar{\boldsymbol{x}})$，即得结论。 ■

熵势给出的常数 在单纯形上，取 $\|\cdot\|=\|\cdot\|_1$，对偶范数是 $\|\cdot\|_\infty$。熵势满足定理的强凸条件。设 $\boldsymbol{v}=\boldsymbol{u}-\boldsymbol{x}$，$\boldsymbol{w}$ 是线段上任一点，$\nabla^2 h(\boldsymbol{w})=\operatorname{diag}(1/w_i)$，由 Cauchy–Schwarz 不等式和 $\sum_i w_i=1$，

$$\boldsymbol{v}^{\top}\nabla^2 h(\boldsymbol{w})\boldsymbol{v}=\sum_i \frac{v_i^2}{w_i}\ge \frac{(\sum_i |v_i|)^2}{\sum_i w_i}=\|\boldsymbol{v}\|_1^2.$$

由 Taylor 公式的积分余项，这给出式 (21.37)，范数取 $\|\cdot\|_1$。

从均匀分布出发，由式 (21.34)和 $\sum_i u_i\ln u_i\le 0$ 得到 $D_h(\boldsymbol{u},\boldsymbol{x}^{(0)})\le \ln n$。在式 (21.38)中取 $\alpha=\sqrt{2\ln n/T}/G$，得到

$$f(\bar{\boldsymbol{x}})-f^{\star}\le G\sqrt{\frac{2\ln n}{T}},\qquad \|\boldsymbol{g}^{(t)}\|_\infty\le G. \tag{21.39}$$

投影次梯度法对同一问题的上界要用 $\|\boldsymbol{g}\|_2$，而 $\|\boldsymbol{g}\|_2$ 可以大到 $\sqrt{n}\,G$。所以梯度稠密时，熵势的上界在维数依赖上小了约 $\sqrt{n/\ln n}$ 倍。这是两个上界的比较，并不保证熵势在每个问题上都更快。

光滑性带来的下降 第二种情形假设 f 相对于 h 光滑，即存在 $L>0$，使 $Lh-f$ 在 $\boldsymbol{C}$ 上凸。把凸性写成切平面不等式，它等价于

$$f(\boldsymbol{u})\le f(\boldsymbol{x})+\langle \nabla f(\boldsymbol{x}),\boldsymbol{u}-\boldsymbol{x}\rangle+LD_h(\boldsymbol{u},\boldsymbol{x}), \tag{21.40}$$

称为**相对光滑**（relative smoothness）。$h=\frac{1}{2}\|\cdot\|_2^2$ 时它就是下降引理。

预算例满足这个条件。单纯形上 $x_i \le 1$，由此

$$\boldsymbol{v}^{\top}\nabla^2 f\,\boldsymbol{v} \le 4\|\boldsymbol{v}\|_2^2 \le 4\sum_i \frac{v_i^2}{x_i} = 4\,\boldsymbol{v}^{\top}\nabla^2 h\,\boldsymbol{v},$$

所以 $L = 4$ 可用，这正是取 $\alpha = 1/4$ 的依据。

定理 21.12　相对光滑下的镜像下降　设 f 凸可微，满足式 (21.40)，各迭代点在 h 的可微区域内，取 $\alpha = 1/L$。则目标逐步下降，

$$f(\boldsymbol{x}^{(t+1)}) \le f(\boldsymbol{x}^{(t)}) - L D_h(\boldsymbol{x}^{(t)}, \boldsymbol{x}^{(t+1)}), \tag{21.41}$$

并且对 $\boldsymbol{u} \in \boldsymbol{C}$，

$$f(\boldsymbol{x}^{(T)}) - f(\boldsymbol{u}) \le \frac{L D_h(\boldsymbol{u}, \boldsymbol{x}^{(0)})}{T}. \tag{21.42}$$

证明　记 $\boldsymbol{x} = \boldsymbol{x}^{(t)}$，$\boldsymbol{x}^{+} = \boldsymbol{x}^{(t+1)}$，$\boldsymbol{g} = \nabla f(\boldsymbol{x})$。由式 (21.40)，

$$f(\boldsymbol{x}^{+}) \le f(\boldsymbol{x}) + \langle \boldsymbol{g}, \boldsymbol{x}^{+} - \boldsymbol{x}\rangle + L D_h(\boldsymbol{x}^{+}, \boldsymbol{x}).$$

在式 (21.36)中取 $\alpha = 1/L$，$\boldsymbol{u} = \boldsymbol{x}$，并用 $D_h(\boldsymbol{x}, \boldsymbol{x}) = 0$，得到

$$\langle \boldsymbol{g}, \boldsymbol{x}^{+} - \boldsymbol{x}\rangle + L D_h(\boldsymbol{x}^{+}, \boldsymbol{x}) \le -L D_h(\boldsymbol{x}, \boldsymbol{x}^{+}).$$

两式合起来就是下降式。

再用凸性给出的切平面下界 $f(\boldsymbol{u}) \ge f(\boldsymbol{x}) + \cdots$，与上面第一式相减，得到

$$f(\boldsymbol{x}^{+}) - f(\boldsymbol{u}) \le \langle \boldsymbol{g}, \boldsymbol{x}^{+} - \boldsymbol{u}\rangle + L D_h(\boldsymbol{x}^{+}, \boldsymbol{x}).$$

用式 (21.36)，右端不超过 $L\big[D_h(\boldsymbol{u}, \boldsymbol{x}) - D_h(\boldsymbol{u}, \boldsymbol{x}^{+})\big]$。对 t 求和裂项，再由目标单调，最后一项不超过平均值，即得结论。 ∎

预算例中 $D_h(\boldsymbol{x}^{\star}, \boldsymbol{x}^{(0)}) \approx 1.263$，$L = 4$，上界约为 $5.05/T$，$T = 60$ 时约为 0.084，实际目标差约 6.6×10^{-5}。

目标不一定下降　定理 21.11只保证平均点，不保证目标逐步下降，下面的例子说明这是真实的。在 $\boldsymbol{\Delta} \subset \mathbb{R}^2$ 上取 $f(\boldsymbol{x}) = |x_1 - x_2|$，$\boldsymbol{x} = (0.6, 0.4)$，次梯度 $\boldsymbol{g} = (1, -1)$，$\alpha = 1$。由式 (21.35)，

$$\boldsymbol{x}^{+} \approx (0.1687, 0.8313), \qquad f(\boldsymbol{x}^{+}) \approx 0.6626.$$

目标从 0.2 升到了 0.6626。次梯度步在不光滑的折点附近可以越过很远，所以输出时应使用平均点，或记录迄今最好的点。表 21.2对比了两种分析。

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.3 条件梯度法（Frank–Wolfe）
21.4 镜像下降
21.5 广义约化梯度法（GRG）
21.5.1 变量分块与局部消元
21.5.2 约化梯度与下降方向
21.5.3 可行恢复与线搜索
21.5.4 界约束与换基
21.6 方法比较
21.7 本章小结

表 21.2 镜像下降的两种分析。

	次梯度分析	相对光滑分析
目标	凸，可不光滑	凸，相对光滑
势函数	按范数强凸	$Lh - f$ 凸
步长	依 T 或递减	$1/L$
目标值单调	否	是
输出	平均点	最后一点
上界的阶	$1/\sqrt{T}$	$1/T$

21.5 广义约化梯度法（GRG）

前三节都依赖集合的凸性。圆周 $y^2 + z^2 = 1$ 上，线段离开了约束，投影也不再有前面的性质。这时怎样从一个可行点走到另一个可行点？接下来要弄清：对光滑非线性约束，如何通过局部消元构造下降方向，又如何解方程回到约束上？

问题的形式 考虑

$$\min_{\boldsymbol{x}} f(\boldsymbol{x}), \qquad \boldsymbol{c}(\boldsymbol{x}) = \boldsymbol{0}, \quad \boldsymbol{l} \le \boldsymbol{x} \le \boldsymbol{u}, \tag{21.43}$$

其中 $\boldsymbol{c} : \mathbb{R}^n \to \mathbb{R}^p$ 连续可微，$p < n$。

不等式约束可以化成这个形式。对 $g_i(\boldsymbol{x}) \le 0$ 引入松弛变量 s_i，改写成 $g_i(\boldsymbol{x}) + s_i = 0$，$s_i \ge 0$。例如 $x_1^2 + x_2^2 \le 1$ 变成 $x_1^2 + x_2^2 + s - 1 = 0$，$s \ge 0$。

主要思想 p 个方程把 n 个变量中的 p 个绑定了。选出 p 个变量让方程去决定，其余 $n - p$ 个变量自由变动，约束问题就在局部变成只含自由变量的问题。这和线性规划单纯形法中“基变量由非基变量决定”的做法相同，只是这里方程非线性，决定关系是一条曲线，要靠隐函数定理保证存在，靠数值解方程求得。

广义约化梯度法（generalized reduced gradient method，GRG）依次做三件事：算自由变量上的下降方向，沿这个方向改变自由变量，再解方程把被绑定的变量拉回约束面。

21.5.1 变量分块与局部消元

选哪些变量由方程决定？选取时要满足什么条件，局部消元才成立？

分块 把变量分成**基本变量**（basic variable）$\boldsymbol{y} \in \mathbb{R}^{p}$ 与**非基本变量**（non-basic variable）$\boldsymbol{z} \in \mathbb{R}^{n-p}$，约束写成 $\boldsymbol{c}(\boldsymbol{y}, \boldsymbol{z}) = \boldsymbol{0}$。对应地，把当前点的 Jacobian 矩阵按列分块，记

$$\boldsymbol{B} = \frac{\partial \boldsymbol{c}}{\partial \boldsymbol{y}} \in \mathbb{R}^{p \times p}, \qquad \boldsymbol{N} = \frac{\partial \boldsymbol{c}}{\partial \boldsymbol{z}} \in \mathbb{R}^{p \times (n-p)}. \tag{21.44}$$

选择分块时有两条要求：$\boldsymbol{B}$ 可逆，基本变量严格位于上下界内。前者保证方程能确定 $\boldsymbol{y}$，后者保证 $\boldsymbol{y}$ 可以朝两边自由调整，用来补偿 $\boldsymbol{z}$ 的变化。图 21.20(a) 是这种分块的示意。

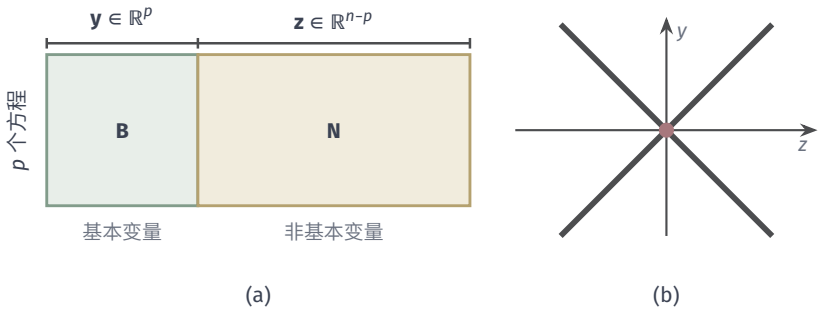


图 21.20 局部消元的前提。(a)$p \times n$ 的 Jacobian 矩阵按变量分成可逆的方块 $\boldsymbol{B}$（绿）和其余部分 $\boldsymbol{N}$（黄）。(b) 约束 $y^2 - z^2 = 0$ 的解集是两条相交直线，红点原点处的 Jacobian 矩阵为零，选哪个变量做基本变量都无法消元。

局部解出基本变量 隐函数定理说：若 $\boldsymbol{c}$ 连续可微，$\boldsymbol{c}(\boldsymbol{y}_0, \boldsymbol{z}_0) = \boldsymbol{0}$，$\boldsymbol{B}$ 在该点可逆，则存在 $\boldsymbol{z}_0$ 的邻域和其上唯一的连续可微函数 $\boldsymbol{y}(\boldsymbol{z})$，满足 $\boldsymbol{y}(\boldsymbol{z}_0) = \boldsymbol{y}_0$，$\boldsymbol{c}(\boldsymbol{y}(\boldsymbol{z}), \boldsymbol{z}) = \boldsymbol{0}$。定理的证明可参考卷二第 22 章“隐函数与反函数”。

把它代入目标，得到只含 $\boldsymbol{z}$ 的**约化目标**（reduced objective）：

$$F(\boldsymbol{z}) = f\big(\boldsymbol{y}(\boldsymbol{z}), \boldsymbol{z}\big). \tag{21.45}$$

F 的定义只要求局部能解出 $\boldsymbol{y}$，并不要求写出显式公式，也不要求全局成立。算法需要 $\boldsymbol{y}(\boldsymbol{z})$ 的值时，就数值解一次方程。

例子 本节用下面的问题贯穿：

$$\min\ y, \qquad y^2 + z^2 = 1. \tag{21.46}$$

全局最优解是 $(y, z) = (-1, 0)$。在点 $(\frac{4}{5}, \frac{3}{5})$，取 y 为基本变量，$B = 2y = \frac{8}{5}$ 可逆，$N = 2z = \frac{6}{5}$。在这个点附近 y 由 z 决定，也就是圆周的上半弧：

$$y(z) = \sqrt{1 - z^2}, \qquad F(z) = \sqrt{1 - z^2}.$$

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.3 条件梯度法（Frank–Wolfe）
21.4 镜像下降
21.5 广义约化梯度法（GRG）
21.5.1 变量分块与局部消元
21.5.2 约化梯度与下降方向
21.5.3 可行恢复与线搜索
21.5.4 界约束与换基
21.6 方法比较
21.7 本章小结

消元只在这一段弧上成立。到 $z=\pm 1$ 处 $B=0$，上半弧到了头。

分块不存在的情形 约束在某点的 Jacobian 矩阵行秩不足时，找不到可逆的 $\boldsymbol{B}$。图 21.20(b) 的 $y^2-z^2=0$ 在原点就是如此：解集是两条直线的交叉，附近根本不是某一个变量的函数。

基本变量都卡在界上也是一种退化：比如能使 $\boldsymbol{B}$ 可逆的列组合都包含位于上下界的变量，这时 $\boldsymbol{y}$ 没有双向调整的余地。这些情形需要另行处理，常用的办法有扰动、改用允许退化的换基规则，或换用第 23章的方法。

21.5.2 约化梯度与下降方向

有了约化目标，它的梯度怎样算？能不能不必真正解出 $\boldsymbol{y}(\boldsymbol{z})$？

推导 沿约束面移动时，一阶变化 $\mathrm{d}\boldsymbol{y}$ 和 $\mathrm{d}\boldsymbol{z}$ 要让 $\boldsymbol{c}$ 不变，所以

$$\boldsymbol{B}\,\mathrm{d}\boldsymbol{y}+\boldsymbol{N}\,\mathrm{d}\boldsymbol{z}=\boldsymbol{0}.$$

解出基本变量的变化：

$$\mathrm{d}\boldsymbol{y}=-\boldsymbol{B}^{-1}\boldsymbol{N}\,\mathrm{d}\boldsymbol{z}. \tag{21.47}$$

$\boldsymbol{z}$ 的改变不是孤立的，$\boldsymbol{y}$ 要跟着改变来补偿。目标的一阶变化是两部分之和：

$$\mathrm{d}F=\langle\nabla_{\boldsymbol{y}}f,\mathrm{d}\boldsymbol{y}\rangle+\langle\nabla_{\boldsymbol{z}}f,\mathrm{d}\boldsymbol{z}\rangle.$$

代入式 (21.47)，把 $\mathrm{d}\boldsymbol{z}$ 提出来，得到**约化梯度**（reduced gradient）：

$$\nabla F=\nabla_{\boldsymbol{z}}f-\boldsymbol{N}^{\top}\boldsymbol{B}^{-\top}\nabla_{\boldsymbol{y}}f. \tag{21.48}$$

计算时不求逆。先解一个方阵方程 $\boldsymbol{B}^{\top}\boldsymbol{\pi}=\nabla_{\boldsymbol{y}}f$，再算 $\nabla F=\nabla_{\boldsymbol{z}}f-\boldsymbol{N}^{\top}\boldsymbol{\pi}$。$\boldsymbol{\pi}$ 是每单位约束变化的价格。线性约束、线性目标时，这个公式就是第 3章的约化成本。

圆周上的计算 在式 (21.46)中，$\nabla_y f=1$，$\nabla_z f=0$。在 $(\tfrac{4}{5},\tfrac{3}{5})$，$B=\tfrac{8}{5}$，$N=\tfrac{6}{5}$，代入式 (21.48)：

$$\nabla F=0-\frac{6}{5}\cdot\frac{5}{8}\cdot 1=-\frac{3}{4}.$$

用显式公式核对：$F'(z)=-z/\sqrt{1-z^2}$，在 $z=\tfrac{3}{5}$ 处正是 $-\tfrac{3}{4}$。

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.3 条件梯度法（Frank–Wolfe）
21.4 镜像下降
21.5 广义约化梯度法（GRG）
21.5.1 变量分块与局部消元
21.5.2 约化梯度与下降方向
21.5.3 可行恢复与线搜索
21.5.4 界约束与换基
21.6 方法比较
21.7 本章小结

这个数的含义可以这样理解。目标本身不含 z，$\nabla_z f = 0$，单看目标似乎改变 z 没有用处。但 z 增加一点，约束的一阶变化要由 y 补偿：$\mathrm{d}y = -\frac{3}{4}\mathrm{d}z$，而 y 就是目标。所以约化梯度记录的是“经过约束传导之后”的影响。图 21.21画出了这个补偿三角形，以及约化目标的切线。

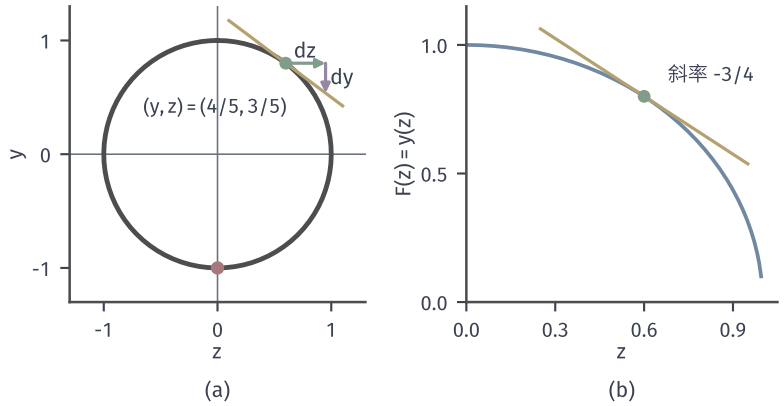


图 21.21 圆周上的约化梯度。(a) 深灰圆是约束，红点是最优解 $(y,z) = (-1,0)$，绿点是当前点，黄线是切线；绿色箭头是 $\mathrm{d}z$，紫色箭头是基本变量的一阶补偿 $\mathrm{d}y = -\frac{3}{4}\mathrm{d}z$。(b) 约化目标 $F(z) = \sqrt{1-z^2}$，在 $z = 3/5$ 处的切线斜率是 $-3/4$。

下降方向 无界约束时可取 $\boldsymbol{d} = -\nabla F$。非基本变量有上下界时，顶在界上又想继续往外走的坐标必须置零：

$$d_j = \begin{cases} 0, & z_j = l_j \text{ 且} (\nabla F)_j > 0, \\ 0, & z_j = u_j \text{ 且} (\nabla F)_j < 0, \\ -(\nabla F)_j, & \text{其他}. \end{cases} \tag{21.49}$$

于是方向导数是

$$\langle \nabla F, \boldsymbol{d} \rangle = -\sum_{j:\, d_j \neq 0} (\nabla F)_j^2 .$$

只要有一个未被置零的坐标，$\boldsymbol{d}$ 就是下降方向。

21.5.3 可行恢复与线搜索

沿切向走一步之后点已经离开约束面。怎样回到约束面，又在哪里评价这一步的好坏？

主要思想 固定候选的 $\boldsymbol{z}^+ = \boldsymbol{z} + \alpha \boldsymbol{d}$，把方程 $\boldsymbol{c}(\boldsymbol{y}, \boldsymbol{z}^+) = \boldsymbol{0}$ 看成只含 $\boldsymbol{y}$ 的 p 个方程，用 Newton 法求解，这个过程称为**可行恢复**（feasibility restoration）。切向预测 $\boldsymbol{y} + \alpha\, \mathrm{d}\boldsymbol{y}$ 是一个已经算好的初值。

步长在恢复后的点上判断，比较 $F(\boldsymbol{z}^{+})$，也就是真实可行点上的目标，而不是切线上的预测值。切线上的目标下降了，不等于回到约束面后依然下降。

变量

- $\boldsymbol{y}^{(t)} \in \mathbb{R}^{p}$，$\boldsymbol{z}^{(t)} \in \mathbb{R}^{n-p}$：当前基本变量与非基本变量，满足约束。
- $\boldsymbol{B}, \boldsymbol{N}$：当前的 Jacobian 分块，见式 (21.44)。
- $\boldsymbol{d}^{(t)} \in \mathbb{R}^{n-p}$：非基本变量的方向。
- α：试探步长；$c_1 \in (0,1)$：Armijo 系数；ε_c：约束残差容差；ε：驻定容差。

初始化 需要一个可行点和一个合格的分块。可行点本身可能要另解一个问题，例如最小化 $\|\boldsymbol{c}(\boldsymbol{x})\|_2^2$。例中从式 (21.46)的可行点出发，取 y 为基本变量，初始试探步长 $\alpha = 1/4$，$c_1 = 0.1$，$\varepsilon_c = 10^{-10}$：

$$(y^{(0)}, z^{(0)}) = \left(\tfrac{4}{5}, \tfrac{3}{5}\right), \qquad F(z^{(0)}) = 0.8.$$

每轮更新 在第 t 轮：

1. **算方向**。由式 (21.48)算约化梯度，由式 (21.49)得 $\boldsymbol{d}^{(t)}$。若 $\|\boldsymbol{d}^{(t)}\|_2 \le \varepsilon$，结束并进入第 21.5.4节的检验。例中第一轮

$$\nabla F = -0.75, \qquad d^{(0)} = 0.75.$$

2. **切向预测**。令 $\boldsymbol{z}^{+} = \boldsymbol{z}^{(t)} + \alpha \boldsymbol{d}^{(t)}$，由式 (21.47)得初值

$$\boldsymbol{y}_0 = \boldsymbol{y}^{(t)} - \boldsymbol{B}^{-1}\boldsymbol{N}\big(\boldsymbol{z}^{+} - \boldsymbol{z}^{(t)}\big). \tag{21.50}$$

例中第一轮

$$z^{+} = 0.7875, \qquad y_0 = 0.659375.$$

3. **Newton 恢复**。反复计算

$$\boldsymbol{y}_{k+1} = \boldsymbol{y}_k - \boldsymbol{B}(\boldsymbol{y}_k, \boldsymbol{z}^{+})^{-1}\boldsymbol{c}(\boldsymbol{y}_k, \boldsymbol{z}^{+}), \tag{21.51}$$

直到 $\|\boldsymbol{c}\|_\infty \le \varepsilon_c$。例中第一轮的各次结果是

$$\begin{aligned} y_0 &= 0.659375, \quad c = 5.49 \times 10^{-2},\\ y_1 &= 0.617721, \quad c = 1.74 \times 10^{-3},\\ y_2 &= 0.616316, \quad c = 1.97 \times 10^{-6},\\ y_3 &= 0.616315, \quad c = 2.56 \times 10^{-12}. \end{aligned}$$

4. **在恢复点上做 Armijo 检验**。要求

$$F(\boldsymbol{z}^{+}) \le F(\boldsymbol{z}^{(t)}) + c_1 \alpha \langle \nabla F, \boldsymbol{d}^{(t)} \rangle.$$

通过就接受，否则把 α 减半回到第 2 步。例中第一轮右端是 0.78594，$F(z^{+}) \approx 0.61631$，接受。

图 21.22(a) 是这一轮的几何。切向预测点（空心）在圆外，Newton 迭代沿竖直方向回到圆上。残差的下降呈二次收敛的样子。

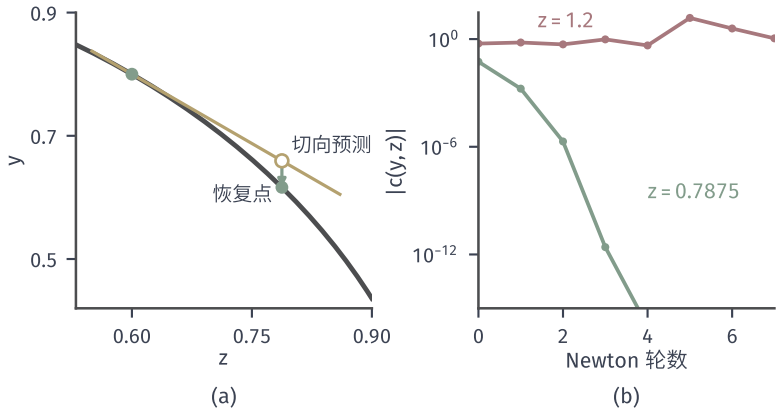


图 21.22 可行恢复。(a) 从绿点沿切线（黄）走到空心点，固定 $z = 0.7875$ 后竖直回到圆周（深灰）。(b)Newton 迭代中 $|c|$ 的变化：绿线 $z = 0.7875$ 迅速收敛；红线 $z = 1.2$，方程 $y^2 + z^2 = 1$ 无实解，残差不减小。

例中第二轮从 $(0.61632, 0.7875)$ 出发，$\nabla F \approx -1.2778$，$d^{(1)} \approx 1.2778$。先试 $\alpha = \frac{1}{4}$，得 $z^+ \approx 1.1069$，超过了 1，方程没有实解，Newton 迭代的残差在几步内不降反升。

于是减半，$\alpha = \frac{1}{8}$，$z^+ \approx 0.94722$，切向预测 $y_0 \approx 0.41223$。Newton 迭代依次给出 0.33077、0.32074、0.32059，残差由 6.7×10^{-2} 降到 2.5×10^{-8}，再一步达到容差。Armijo 检验的右端约为 0.5959，$F(z^+) \approx 0.32059$，接受：

$$(y^{(2)}, z^{(2)}) \approx (0.32059, 0.94722).$$

例中第三轮 $\nabla F \approx -2.955$，方向更陡，而 z 离 1 只剩 0.053。试探步长要连续减半四次到 $\alpha = \frac{1}{64}$，得到 $z^+ \approx 0.9934$，$y \approx 0.1148$。此时 $B = 2y \approx 0.23$ 已经很小，继续下去方程越来越病态，上半弧也快到头了。下一小节处理这个问题。

恢复失败时 Newton 迭代不收敛有几种可能的原因，处理也不同：步子太大，切向预测离约束面太远，办法是缩短 α；Jacobian 矩阵过时，办法是重新计算；$\boldsymbol{B}$ 接近奇异，办法是换基。

恢复失败和原问题无可行解是两回事。第二轮的 $z = 1.1069$ 处方程无解，可是当前点 $(0.61632, 0.7875)$ 本身可行。恢复失败只说明这个候选的 $\boldsymbol{z}^+$ 在这个分块下没有对应的可行点。

恢复容差与 Jacobian 更新 恢复的容差要按原约束残差 $\|\boldsymbol{c}\|_\infty$ 设置，不能按 Newton 步的长度设置。步长短不等于残差小，$\boldsymbol{B}$ 病态时尤其如此。

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.3 条件梯度法（Frank–Wolfe）
21.4 镜像下降
21.5 广义约化梯度法（GRG）
21.5.1 变量分块与局部消元
21.5.2 约化梯度与下降方向
21.5.3 可行恢复与线搜索
21.5.4 界约束与换基
21.6 方法比较
21.7 本章小结

为了省计算，实现中常常冻结 $\boldsymbol{B}$，每次 Newton 迭代只重新算残差。这样收敛变成线性的。第一轮冻结 $B=1.6$ 时，残差依次是

$$5.49\times10^{-2},\quad 1.08\times10^{-2},\quad 2.42\times10^{-3},\quad 5.51\times10^{-4},$$

每次大约缩小 4.5 倍。省下分解矩阵的钱，要用更多的残差计算来付。残差下降变慢时就该更新 $\boldsymbol{B}$。

21.5.4 界约束与换基

上面的例子留下两个问题：分块何时必须更换？算法停下来时，怎样判断这个点满足原问题的最优性条件？

一阶必要性 第 17章的 KKT 条件要求：存在等式乘子和上下界乘子 $\boldsymbol{\lambda}^{l},\boldsymbol{\lambda}^{u}\ge\mathbf{0}$，使 Lagrange 函数的梯度为零，并满足互补条件。对问题 (21.43)，这个条件可以用约化梯度来检验。

定理 21.13 约化梯度与 KKT 条件 设 $\boldsymbol{x}=(\boldsymbol{y},\boldsymbol{z})$ 满足式 (21.43)的约束，$\boldsymbol{B}$ 可逆，$\boldsymbol{l}_{\boldsymbol{y}}<\boldsymbol{y}<\boldsymbol{u}_{\boldsymbol{y}}$。则 $\boldsymbol{x}$ 满足 KKT 条件，当且仅当约化梯度 (21.48)的每个分量满足

$$(\nabla F)_j\begin{cases}\ge 0, & z_j=l_j,\\ \le 0, & z_j=u_j,\\ =0, & l_j<z_j<u_j.\end{cases}\tag{21.52}$$

此时等式乘子是 $\boldsymbol{\nu}=-\boldsymbol{B}^{-\top}\nabla_{\boldsymbol{y}}f$。

证明 KKT 条件的驻定部分按两组变量写开。基本变量严格在界内，互补性使它们的上下界乘子为零，所以

$$\nabla_{\boldsymbol{y}}f+\boldsymbol{B}^{\top}\boldsymbol{\nu}=\mathbf{0}.$$

$\boldsymbol{B}$ 可逆，这唯一地确定 $\boldsymbol{\nu}=-\boldsymbol{B}^{-\top}\nabla_{\boldsymbol{y}}f$。

非基本变量的驻定条件是

$$\nabla_{\boldsymbol{z}}f+\boldsymbol{N}^{\top}\boldsymbol{\nu}-\boldsymbol{\lambda}_{\boldsymbol{z}}^{l}+\boldsymbol{\lambda}_{\boldsymbol{z}}^{u}=\mathbf{0}.$$

把 $\boldsymbol{\nu}$ 代入，前两项之和正是 ∇F，于是

$$\nabla F=\boldsymbol{\lambda}_{\boldsymbol{z}}^{l}-\boldsymbol{\lambda}_{\boldsymbol{z}}^{u}.$$

> 由互补性，$z_j = l_j$ 时 $\lambda_j^u = 0$，$(\nabla F)_j = \lambda_j^l \geq 0$；$z_j = u_j$ 时 $(\nabla F)_j = -\lambda_j^u \leq 0$；在界内时两个乘子都是零，$(\nabla F)_j = 0$。反过来，满足式 (21.52)时，按这三种情况取乘子就得到 KKT 条件。 ■

用圆周例检验。加上界 $z \leq \frac{3}{5}$，点 $(\frac{4}{5}, \frac{3}{5})$ 处非基本变量在上界，$\nabla F = -\frac{3}{4} \leq 0$，符号条件成立。此时 $\nu = -\frac{5}{8}$，上界乘子是 $\frac{3}{4}$，这个点是带界问题的最优解。若没有这个上界，$\nabla F \neq 0$，它就不是驻点。

基本变量碰界 非基本变量的界由式 (21.49)控制，基本变量是被动的，可能在恢复时越界。例如给圆周例加上 $y \geq 0.7$，从 $(0.8, 0.6)$ 沿 $d = 0.75$ 前进。

用切线估计，y 降到 0.7 的步长是 $0.1/0.5625 \approx 0.178$。但恢复后的点在 $z = 0.7333$ 处有 $y \approx 0.680$，已经越界。所以步长要按恢复后的点限制，真实的碰界点在

$$z = \sqrt{1 - 0.49} \approx 0.71414, \qquad \alpha \approx 0.1522.$$

这时 y 到达下界，不再满足“严格在界内”的要求，要做一次换基：y 变成非基本变量，固定在下界；z 变成基本变量，$B = 2z \approx 1.428$ 可逆。新的约化目标是 $F(y) = y$，$\nabla F = 1 \geq 0$，y 在下界，条件 (21.52)成立。这个点 $(0.7, 0.71414)$ 就是带界问题的最优解。

基矩阵病态时换基 即使没有碰界，$\boldsymbol{B}$ 接近奇异也要换基。上一小节例子的第三轮已经看到：$|B|$ 变小，约化梯度变陡，步长被压得很短。

一个简单的规则是每轮选取主元较大的变量做基本变量。圆周例只有一个方程，两列分别是 $2y$ 和 $2z$，当 $|y| < |z|$ 时让 z 做基本变量。多个方程时，这相当于带列主元的矩阵分解选取一组条件数较好的列。图 21.23从 $(0.8, 0.6)$ 出发，取固定步长 $\alpha = 1/4$。第二轮起 $|y| < |z|$，基本变量换成 z，新的约化目标 $F(y) = y$ 的梯度是 1，迭代沿圆周平稳越过 $(y, z) = (0, 1)$。等到 $|z| < |y|$ 再换回 y，最后收敛到 $(-1, 0)$。

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.3 条件梯度法（Frank–Wolfe）
21.4 镜像下降
21.5 广义约化梯度法（GRG）
21.6 方法比较
21.6.1 内层精度
21.6.2 结果检验
21.7 本章小结

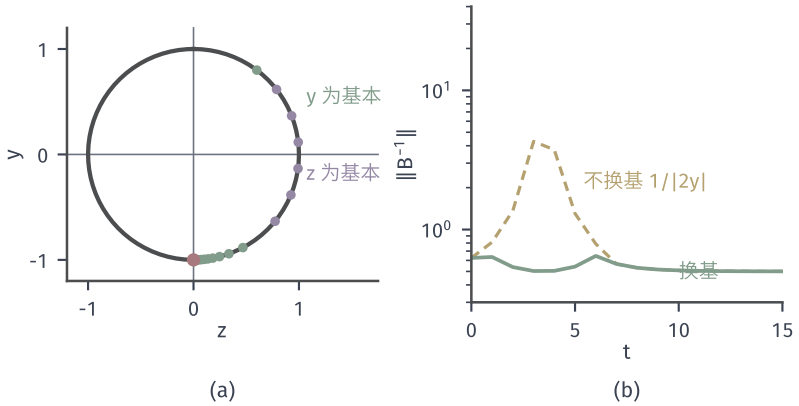


图 21.23 换基的效果，问题 (21.46)，从 $(0.8, 0.6)$ 出发，步长 $1/4$。(a) 迭代点的颜色表示当轮的基本变量：绿色为 y，紫色为 z，红点是最优解。(b) 沿同一路径的 $\|\boldsymbol{B}^{-1}\|$：黄色虚线是始终以 y 为基本变量时的 $1/|2y|$，路径经过 $y \approx 0$ 附近时急剧增大；绿线是每轮换基后的值，保持有界。

运行中要监测什么 GRG 实现要持续监测三类量：$\boldsymbol{B}$ 的条件数，太大就换基；原始可行性 $\|\boldsymbol{c}(\boldsymbol{x})\|_\infty$ 和界的违反量；KKT 残差，也就是式 (21.52)的违反程度。

每步可行不等于全局最优 局部表示、可行恢复和换基都有条件，任何一个失败，算法就要改变动作。即使全部成功，得到的也只是满足一阶条件的点。在圆周例中，点 $(y, z) = (1, 0)$ 的约化梯度为零，它满足 KKT 条件，却是目标的最大点。从恰好这一点出发，方法不会移动。约束非凸时，每步可行和目标下降都推不出全局最优。

21.6 方法比较

前面四种方法该怎样选？本节先按集合结构筛选，再谈成本。比较的前提是同一个问题确实满足所比较方法的条件，并且用相同的可行精度和相同的最优性度量。

先看集合 选择的第一步是问集合支持什么运算。闭凸集合上可以选投影、线性最小化或 Bregman 子问题；光滑非线性等式约束只有 GRG 的局部消元和解方程这条路，前三种方法的保证不适用。反过来，单纯形这样的简单集合也用不着 GRG。把适用集合不同的方法排成统一的优劣次序没有意义。

同一问题上的比较 三种闭凸方法都能解预算例。图 21.24(a) 显示投影梯度最快，因为投影的代价在单纯形上很低，解又落在一条边上，活动集识别后就是一维问题。

21.1　可行集合上的更新
21.2　投影梯度法（PGD）
21.3　条件梯度法（Frank–Wolfe）
21.4　镜像下降
21.5　广义约化梯度法（GRG）
21.6　方法比较
21.6.1　内层精度
21.6.2　结果检验
21.7　本章小结

图 21.24(b) 换成高维单纯形上的最小二乘问题，看解的稀疏性。条件梯度的非零元个数从一开始缓慢增长，始终很少；投影梯度从稠密起点迅速截断；镜像下降一直保持全部为正。条件梯度的稀疏只是说输出的表示短，并不说明它更准确。

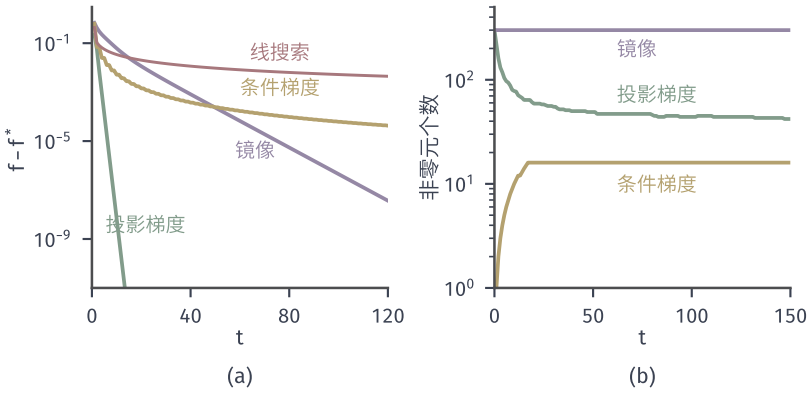


图 21.24　同一单纯形问题上的比较。(a) 预算例的迄今最小目标差：绿线投影梯度，紫线镜像下降，黄线条件梯度（预定序列），红线条件梯度（线搜索）。(b)$n = 300$ 的单纯形最小二乘，随机矩阵 $\boldsymbol{A} \in \mathbb{R}^{60\times 300}$（种子固定），绿线投影梯度和紫线镜像下降从均匀分布出发，黄线条件梯度从一个顶点出发，纵轴是非零元个数。

表 21.3归纳了单纯形上每轮的成本和结构。总成本是每轮成本乘以达到相同精度所需的轮数，只看其中一个因子会得出错误的结论。

表 21.3　n 维单纯形上三种方法每轮的额外运算（梯度计算另计）。

方法	额外运算	输出结构	活动约束
投影梯度	排序，$O(n \log n)$	可稀疏	有限步后常被识别
条件梯度	找最小分量，$O(n)$	顶点的短组合	基本流程难以识别
镜像下降	乘法与归一化，$O(n)$	全部为正	不精确识别

21.6.1　内层精度

每种方法的子问题都可能只能近似求解。这些内层误差分别影响哪里，又该解到多准？

误差进入的位置　表 21.4按方法列出内层误差的去向。投影和 GRG 的恢复直接影响可行性，线性最小化的误差只影响下降和证书，因为不精确的顶点仍在集合内。

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.3 条件梯度法（Frank–Wolfe）
21.4 镜像下降
21.5 广义约化梯度法（GRG）
21.6 方法比较
21.6.1 内层精度
21.6.2 结果检验
21.7 本章小结

表 21.4 内层误差的影响。

内层计算	可行性	下降	停止检验
投影	可能略不可行	式 (21.16)	残差误差 ε/α
线性最小化	不受影响	式 (21.23)	间隙加 ε
镜像子问题	视解法而定	三点关系多余项	同步记录误差
GRG 恢复	残差至多 ε_c	F 的值有误差	须检查 $\boldsymbol{c}$

熵势在单纯形上的子问题有闭式解，归一化的舍入误差可以忽略。一般的集合上，镜像子问题也要迭代求解，并且三点关系 (21.36)多出误差项，处理方式和近似投影类似。

按外层精度安排内层 外层离解还远时，把内层解到很高的精度是浪费；外层接近收敛时，内层误差又会成为瓶颈。前面的递推说明了这一点：式 (21.23)让线性最小化的容差随 $\alpha^{(t)}$ 减小，式 (21.16)说明投影容差决定了误差的平台。常用做法是把内层容差设成外层当前残差的一个比例。

GRG 的恢复容差则有一个硬性的下限要求：它决定了输出点的可行程度，至少要达到最终要求的约束精度。

成本要算全 GRG 每轮的成本不只是外层更新，要把下面各项都算进去：

- 线搜索中重复的恢复，每次试探步长都要解一次非线性方程；
- 每次恢复中的 Newton 迭代，各需一次约束计算和一次线性方程求解；
- Jacobian 矩阵的更新与 $\boldsymbol{B}$ 的分解，稠密时分解约需 p^3 量级的运算；
- 换基之后的重新分解或分解修正。

上面圆周例的第三轮就要试探五个步长，其中四个失败或被拒绝，这些计算都要计入总成本。投影梯度的回溯同样要计入重复投影的次数。比较方法时，统计的是这些基本运算的总次数，而不是外层轮数。

21.6.2 结果检验

算法停下来之后，应该报告什么数字来证明结果可用？

凸问题 凸问题可以报告目标差的上界。条件梯度的间隙 Γ 直接就是这样的上界。单纯形上计算 Γ 只要 $O(n)$，投影梯度或镜像下降也可以顺便算一个间隙作为证书。

21.1 可行集合上的更新
21.2 投影梯度法（PGD）
21.3 条件梯度法（Frank–Wolfe）
21.4 镜像下降
21.5 广义约化梯度法（GRG）
21.6 方法比较
21.7 本章小结

没有线性最小化可用时，投影残差也能给出上界。在定理 21.5的证明中取 $\mu=0$，$\alpha=1/L$，$\boldsymbol{y}=\boldsymbol{x}^{\star}$，由内积的上界和残差的定义，得到

$$f(\boldsymbol{x}^{+})-f^{\star}\le \|\boldsymbol{G}_{\alpha}(\boldsymbol{x})\|_2\|\boldsymbol{x}^{+}-\boldsymbol{x}^{\star}\|_2+\frac{1}{2L}\|\boldsymbol{G}_{\alpha}(\boldsymbol{x})\|_2^2. \tag{21.53}$$

这需要知道到解的距离的上界，比如集合的直径，否则残差小不能换算成目标差小。

非凸光滑问题　目标非凸时报告驻定度量，$\|\boldsymbol{G}_{\alpha}\|_2$ 或 Γ 都可以，同时要说明步长，并明确它只检验一阶条件。

GRG　GRG 的报告必须回到原问题的形式：$\|\boldsymbol{c}(\boldsymbol{x})\|_{\infty}$、界的违反量、以及完整的 KKT 残差。只看约化梯度的范数是不够的。在圆周例的不可行点 $(y,z)=(2,0)$ 上，公式 (21.48)算出 $\nabla F=0$，而约束残差是 3。约化梯度的含义依赖于“当前点在约束面上”这个前提。

随机方向　大规模时梯度常常用随机估计代替。第 13章的分析依赖更新对噪声是线性的，这样条件期望可以直接进入更新。投影和指数映射都是非线性的，期望不能穿过去。

取 $\boldsymbol{C}=[0,1]$，$x=0$，随机梯度等概率取 ±1，期望是零。精确梯度的投影更新留在原地，而随机更新的期望是

$$\mathbb{E}\big[P_{\boldsymbol{C}}(x-\alpha\tilde{g})\big]=\tfrac{1}{2}\alpha+\tfrac{1}{2}\cdot 0=\tfrac{\alpha}{2}\neq 0.$$

指数映射也是如此：

$$\mathbb{E}\big[\exp(-\alpha\tilde{g})\big]=\cosh\alpha>1=\exp\big(-\alpha\,\mathbb{E}[\tilde{g}]\big).$$

所以把随机方向接入投影或镜像更新时，要在变分不等式或三点关系那一层使用条件期望，也就是对内积取期望，然后单独控制噪声带来的二次项，不能把噪声当成在映射之外平均掉。

21.7 本章小结

本章的问题是怎样让每个迭代点满足原约束，以及保持或恢复可行性要花多少计算。预算例给出了同一问题上的对比，圆周例说明了凸集之外的情形。

投影梯度把梯度步拉回最近点，残差 $\boldsymbol{G}_{\alpha}$ 为零等价于变分不等式，L 光滑时目标差有 $1/T$ 的界，强凸时距离线性收缩。条件梯度只用线性最小化，靠凸组合保持可行，产生顶点的短组合，间隙 Γ 在凸问题上上界目标差。

镜像下降把欧氏距离换成 Bregman 距离，在单纯形上给出保持正性的指数更新；一般次梯度分析针对平均点，只有相对光滑时目标才逐步下降。

GRG 面向光滑非线性约束，通过可逆的基矩阵局部消元，按约化梯度移动非基本变量，再解方程恢复基本变量，碰界或病态时换基。它依赖的是局部可解性，与前三种方法的闭凸集假设不同，两边的保证不能互相借用。

各种方法都要分别检查原约束误差和合适的最优性残差。内层投影、线性最小化或恢复不精确时，误差要进入递推和停止检验。可行迭代还需要一个可行的起点，这个起点本身有时也要专门构造。

第 22 章

惩罚与乘子方法

两家工厂要合计生产 4 个单位，产量分别为 x_1 和 x_2，成本分别是 $\frac{1}{2}x_1^2$ 和 $\frac{3}{2}x_2^2$。问题写出来是

$$\min_{\boldsymbol{x}\in\mathbb{R}^2} \; f(\boldsymbol{x}) = \frac{1}{2}x_1^2 + \frac{3}{2}x_2^2 \qquad \text{s.t.} \qquad h(\boldsymbol{x}) = x_1 + x_2 - 4 = 0. \tag{22.1}$$

消去一个变量，或者解 KKT 方程，可以得到 $\boldsymbol{x}^\star = (3,1)$，最优值 $f^\star = 6$。这条约束是线性的，第 21章的做法可以每一步都留在直线上。一旦约束弯曲，或者有成千上万条，每一步都保持可行就可能比原问题还难。

本章走另一条路：允许迭代点暂时违反约束，让违反本身产生一个信号，再由信号把点拉回来。工厂的例子里有两种自然的信号。一种是罚款：总产量偏离 4 就按偏离量收钱。另一种是价格：总部报出一个单价，两家工厂各自决定产量，总量不够就提价，过多就降价。

这两种信号各有毛病。罚款要想把违规压到零，必须重到无穷大，内层问题随之越来越难解；价格不增加任何曲率，步子一大就来回振荡，而且目标线性时根本定不出产量。全章的路线是：先把两种信号各自讲透，第 22.1节和第 22.2节讲罚款，第 22.3节讲价格；再把它们合在一个函数里，第 22.4节看到两者的毛病恰好互相弥补；第 22.5节进一步问，变量分成两块时能否一块一块地更新。

式 (22.1)贯穿全章，用来比较各种方法。另一个例子更小，只有一个变量和一条不等式约束：

$$\min_{x\in\mathbb{R}} \; x \qquad \text{s.t.} \qquad 1 - x \le 0, \tag{22.2}$$

它的解是 $x^\star = 1$，乘子 $\lambda^\star = 1$。下文分别称为二元例和一维例。全章讨论的一般问题是

$$\min_{\boldsymbol{x}\in\mathbb{R}^n} \; f(\boldsymbol{x}) \quad \text{s.t.} \quad g_i(\boldsymbol{x}) \le 0 \,(i = 1,\dots,m), \quad h_j(\boldsymbol{x}) = 0 \,(j = 1,\dots,p), \tag{22.3}$$

可行集记作 $\boldsymbol{C}$。原始可行、Lagrange 驻定、全局证书是三件不同的事，第 17章和第 18章已经分别建立，本章每种方法结束时都要回到这三项上逐一核对。

22.1 二次惩罚法
22.1.1 罚参数的更新
22.1.2 极限与病态
22.2 精确惩罚法
22.3 对偶上升
22.4 增广 Lagrange 法（ALM）
22.5 交替方向乘子法（ADMM）
22.6 方法比较与计算成本
22.7 本章小结

22.1 二次惩罚法

把约束换成目标里的一笔费用之后，得到的解离原问题有多远，又要付出什么代价？

给违规计价 可以把约束想成预算。硬约束相当于一分钱都不许超；惩罚的做法是允许超，但超得越多罚得越狠。费用要满足两点：可行时为零，不改变可行点上的目标；违规时为正，并且最好是光滑的，这样前面的无约束方法可以直接使用。

平方正好满足这两点。等式残差 h_j 偏离零时收 h_j^2。不等式只有 $g_i>0$ 时才算违规，所以先取正部

$$[a]_+=\max\{a,0\},$$

再平方。把两类费用加到目标上，就得到下面的函数。

定义 22.1 二次罚函数 对问题 (22.3)和罚参数（penalty parameter）$\rho>0$，二次罚函数（quadratic penalty function）是

$$Q_\rho(\boldsymbol{x})=f(\boldsymbol{x})+\frac{\rho}{2}\Big(\sum_{i=1}^{m}[g_i(\boldsymbol{x})]_+^2+\sum_{j=1}^{p}h_j(\boldsymbol{x})^2\Big). \tag{22.4}$$

依次近似最小化 Q_ρ 并逐步增大 ρ 的做法称为二次惩罚法（quadratic penalty method）。

迭代点一般从可行集外面逼近，所以这类方法也叫外点法。正部的平方虽然含有 max，导数却是连续的：$\phi(a)=[a]_+^2$ 在 $a<0$ 时为零，在 $a>0$ 时为 a^2，两边在 $a=0$ 处的导数都是 0，因此 $\phi'(a)=2[a]_+$。由链式法则，当 f,g_i,h_j 都连续可微时，

$$\nabla Q_\rho(\boldsymbol{x})=\nabla f(\boldsymbol{x})+\rho\sum_{i=1}^{m}[g_i(\boldsymbol{x})]_+\nabla g_i(\boldsymbol{x})+\rho\sum_{j=1}^{p}h_j(\boldsymbol{x})\nabla h_j(\boldsymbol{x}). \tag{22.5}$$

要注意 ϕ'' 在 $a=0$ 处跳跃，所以有不等式约束时 Q_ρ 一般只是一阶连续可微，二阶导数在约束边界上不连续。

示例 22.2 一维例的二次罚 式 (22.2)的 $g(x) = 1 - x$，罚函数是

$$Q_\rho(x) = x + \frac{\rho}{2}[1 - x]_+^2.$$

当 $x \geq 1$ 时，$Q_\rho'(x) = 1 > 0$，这部分没有驻点。当 $x < 1$ 时，

$$Q_\rho'(x) = 1 - \rho(1 - x).$$

令其为零，解出

$$x_\rho = 1 - \frac{1}{\rho}.$$

Q_ρ 是凸函数，所以这个驻点是全局最小点。它落在可行集外，违规量恰好是 $1/\rho$。

图 22.1画出 $\rho = 1, 2, 5$ 时的 Q_ρ。绿点随 ρ 增大向右移动，始终停在竖线左边，不可行。绿点的高度是 $Q_\rho(x_\rho) = 1 - 1/(2\rho)$，比原问题的最优值 1 低。可见罚目标的值既不是原目标，也不是最优值的上界，降低罚目标和满足原约束是两件要分别检查的事。

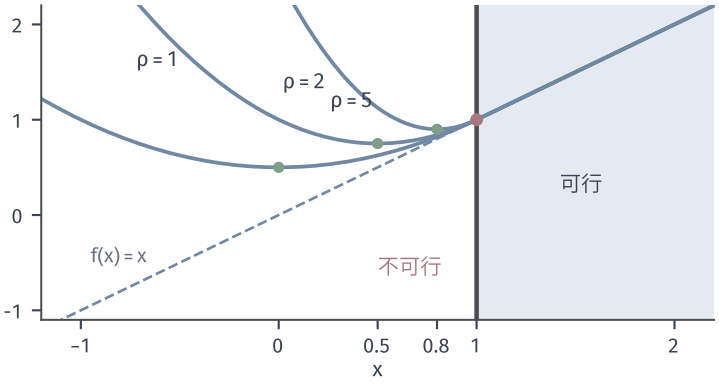


图 22.1 一维例的二次罚函数，$\rho = 1, 2, 5$。蓝色实线是 Q_ρ，蓝色虚线是原目标 $f(x) = x$，浅蓝区域是可行集，深灰竖线是约束边界。绿点是 Q_ρ 的最小点 $x_\rho = 1 - 1/\rho$，红点是原问题的解。有限的 ρ 下最小点总在边界左侧。

力的平衡 为什么有限的 ρ 总留下违规？把驻点方程 $\rho(1 - x_\rho) = 1$ 读成力的平衡。目标以大小为 1 的力把 x 往左拉，罚项像一根劲度为 ρ 的弹簧往右推。弹簧必须被拉长才有力，要平衡 1 的力就得拉长 $1/\rho$。弹簧越硬，拉长越少，但只要力不为零，拉长量就不为零。

这个力的大小 $\rho(1 - x_\rho) = 1$ 恰好是最优乘子 $\lambda^\star = 1$。第 17章说过，乘子度量约束对目标的反作用力。这里违规量乘罚参数等于乘子，并不是一维例的巧合，后面会看到它的一般形式。类比也有失效的地方：真实的弹簧两边都有力，而不等式的罚项只在违规一侧起作用。

22.1 二次惩罚法
22.1.1 罚参数的更新
22.1.2 极限与病态
22.2 精确惩罚法
22.3 对偶上升
22.4 增广 Lagrange 法（ALM）
22.5 交替方向乘子法（ADMM）
22.6 方法比较与计算成本
22.7 本章小结

示例 22.3　二元例的二次罚　对式 (22.1)，罚函数是

$$Q_\rho(\boldsymbol{x}) = \frac{1}{2}x_1^2 + \frac{3}{2}x_2^2 + \frac{\rho}{2}(x_1 + x_2 - 4)^2.$$

令梯度为零，得到两个线性方程：

$$(1+\rho)x_1 + \rho x_2 = 4\rho, \qquad \rho x_1 + (3+\rho)x_2 = 4\rho.$$

两式相减得 $x_1 = 3x_2$。代回第二式，解出

$$x_2(\rho) = \frac{4\rho}{3+4\rho}, \qquad x_1(\rho) = \frac{12\rho}{3+4\rho}. \tag{22.6}$$

由此算出约束残差

$$h(\boldsymbol{x}(\rho)) = -\frac{12}{3+4\rho}. \tag{22.7}$$

它在 $\rho \to \infty$ 时以 $1/\rho$ 的速度趋于零，而 $\rho h(\boldsymbol{x}(\rho))$ 趋于 -3，正是 $\nu^\star$。

图 22.2是同一个例子的二维图景。深灰直线是约束，绿点是 Q_ρ 的最小点。ρ 增大时等高线沿直线方向被拉长，绿点向红点靠近。

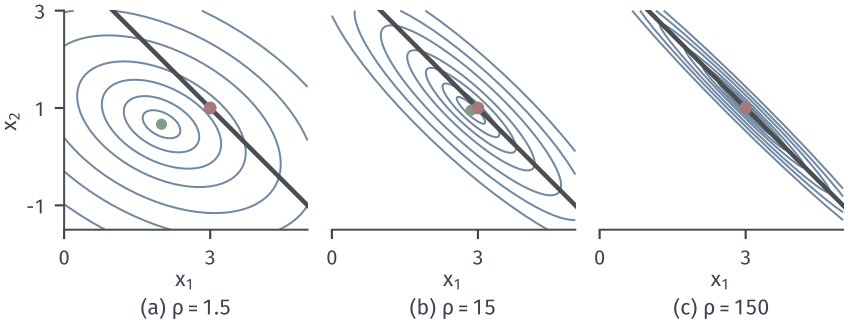


图 22.2　二元例中 Q_ρ 的等高线（蓝）。深灰直线是约束 $x_1 + x_2 = 4$，绿点是 Q_ρ 的最小点，红点是原问题的解 $(3, 1)$。ρ 增大时最小点靠近解，等高线同时变成贴着约束的狭长椭圆。

22.1.1 罚参数的更新

主要思想　式 (22.7)提示一开始就把 ρ 取得很大，一次解完。这样做的问题在于，ρ 大的罚问题很难解，本节后面会算出来。如果从不好的初值开始，内层算法可能花大量步数才能进入解的附近。

合理的做法是沿着 ρ 的路径走。先取较小的 ρ，解一个容易的问题；再放大 ρ，以上一轮的解作为初值。ρ 只放大有限倍时，新解离旧解不远，这叫**热启动**（warm start）。外层循环的结构如图 22.3所示。

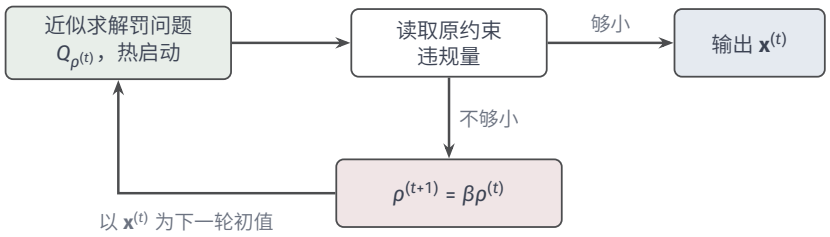


图 22.3　二次惩罚法的外层循环。绿框是内层的无约束求解，蓝框是输出；判断依据是原约束的违规量，而不是罚目标的大小。只有违规量不够小时才放大罚参数（红框）。

这里有两个容差，分工不同。内层容差 $\omega^{(t)}$ 控制 $\|\nabla Q_{\rho^{(t)}}(\boldsymbol{x}^{(t)})\|_2$，说明这一轮的罚问题解得多准。外层容差 ε 控制原约束的违规量，说明原问题的可行性够不够。内层梯度很小，只说明罚问题解好了，不能据此宣布原问题已解。

放大规则取固定倍数 $\beta > 1$，并记录乘子估计：

$$\rho^{(t+1)} = \beta\rho^{(t)}, \qquad \nu_j^{(t)} = \rho^{(t)} h_j(\boldsymbol{x}^{(t)}), \qquad \lambda_i^{(t)} = \rho^{(t)}[g_i(\boldsymbol{x}^{(t)})]_+. \tag{22.8}$$

这组估计的来历可以从式 (22.5)读出：把它们代入，∇Q_ρ 恰好是 Lagrange 函数对 $\boldsymbol{x}$ 的梯度。内层求解到梯度为零，就等于 Lagrange 驻定条件在这组估计下成立。

计算过程　以二元例为例，内层用步长为 $1/L$ 的梯度法，其中 L 是 $\nabla^2 Q_\rho$ 的最大特征值。

变量

- $\boldsymbol{x}^{(t)} \in \mathbb{R}^n$：第 t 轮罚问题的近似解。例中 $n = 2$。
- $\rho^{(t)} > 0$：罚参数，放大倍数为 $\beta > 1$。
- ε、$\omega^{(t)}$：外层违规容差、内层梯度容差。

初始化　取初值 $\boldsymbol{x}^{(-1)}$、$\rho^{(0)} > 0$ 和 β。例中 $\boldsymbol{x}^{(-1)} = (0, 0)$, $\rho^{(0)} = 1.5$, $\beta = 10$, 外层容差 $\varepsilon = 0.05$，内层容差取常数 $\omega^{(t)} = 10^{-3}$。

每轮更新

1. 从 $\boldsymbol{x}^{(t-1)}$ 出发近似最小化 $Q_{\rho^{(t)}}$，直到梯度范数不超过 $\omega^{(t)}$。例中第一轮用了 21 个梯度步，结果接近式 (22.6)的精确解，以下数值用精确解给出：

$$\boldsymbol{x}^{(0)} = \left(2,\ \frac{2}{3}\right).$$

22.1 二次惩罚法
22.1.1 罚参数的更新
22.1.2 极限与病态
22.2 精确惩罚法
22.3 对偶上升
22.4 增广 Lagrange 法（ALM）
22.5 交替方向乘子法（ADMM）
22.6 方法比较与计算成本
22.7 本章小结

2. 计算违规量。例中第一轮

$$h(\boldsymbol{x}^{(0)}) = -\frac{4}{3}, \qquad |h(\boldsymbol{x}^{(0)})| > \varepsilon.$$

3. 若违规量不超过 ε，结束；否则由式 (22.8)放大罚参数并记录乘子估计。例中第一轮

$$\rho^{(1)} = 15, \qquad \nu^{(0)} = 1.5 \times \left(-\frac{4}{3}\right) = -2.$$

例中第二轮从 $\boldsymbol{x}^{(0)}$ 热启动，用了 107 个梯度步，得到

$$\boldsymbol{x}^{(1)} = \left(\frac{20}{7}, \frac{20}{21}\right), \qquad h(\boldsymbol{x}^{(1)}) = -\frac{4}{21} \approx -0.190.$$

乘子估计是 $\nu^{(1)} = -\frac{20}{7} \approx -2.857$。违规量仍大于 0.05，于是 $\rho^{(2)} = 150$。第三轮用了 725 个梯度步，得到

$$\boldsymbol{x}^{(2)} = \left(\frac{200}{67}, \frac{200}{201}\right), \qquad h(\boldsymbol{x}^{(2)}) = -\frac{4}{201} \approx -0.020.$$

乘子估计是 $\nu^{(2)} = -\frac{200}{67} \approx -2.985$。

结束条件是违规量不超过 ε，例中在第三轮满足。最终得到 $\boldsymbol{x}^{(2)} \approx (2.985, 0.995)$，目标值 $f(\boldsymbol{x}^{(2)}) \approx 5.940$，略低于 $f^\star = 6$，这是因为点还不可行。三轮的梯度步数依次是 21、107、725，几乎全部花在最后一轮上。步数为什么增长这么快，正是下一小节要回答的。

22.1.2 极限与病态

这一小节回答两个问题：$\rho \to \infty$ 时迭代点到底趋于什么，以及这条路有多贵。

全局解的极限 先看最理想的情形，每一轮都得到罚问题的全局最小点。此时可以把罚目标与任意一个可行点比较，这个比较给出全部结论。

定理 22.4 二次惩罚法的全局极限 设 f、g_i、h_j 在 $\mathbb{R}^n$ 上连续，可行集 $\boldsymbol{C}$ 非空，且 f 在 $\mathbb{R}^n$ 上有下界 f_{low}。设 $\rho^{(t)} \to \infty$，每个 $\boldsymbol{x}^{(t)}$ 都是 $Q_{\rho^{(t)}}$ 的全局最小点。记

$$v(\boldsymbol{x}) = \sum_{i=1}^{m} [g_i(\boldsymbol{x})]_+^2 + \sum_{j=1}^{p} h_j(\boldsymbol{x})^2. \tag{22.9}$$

则对任一可行点 $\bar{\boldsymbol{x}} \in \boldsymbol{C}$，有

$$v(\boldsymbol{x}^{(t)}) \le \frac{2\big(f(\bar{\boldsymbol{x}}) - f_{\mathrm{low}}\big)}{\rho^{(t)}}, \tag{22.10}$$

并且 $\{\boldsymbol{x}^{(t)}\}$ 的每个聚点都是原问题的全局最优解。

证明　可行点上罚项为零，$Q_{\rho^{(t)}}(\bar{\boldsymbol{x}}) = f(\bar{\boldsymbol{x}})$。$\boldsymbol{x}^{(t)}$ 是全局最小点，所以

$$f(\boldsymbol{x}^{(t)}) + \frac{\rho^{(t)}}{2} v(\boldsymbol{x}^{(t)}) \le f(\bar{\boldsymbol{x}}).$$

左边第一项用 f_{low} 放缩，整理即得式 (22.10)。

设 $\hat{\boldsymbol{x}}$ 是一个聚点，子列收敛到它。v 连续，而式 (22.10)的右边趋于零，所以 $v(\hat{\boldsymbol{x}}) = 0$，即 $\hat{\boldsymbol{x}}$ 可行。

上面的不等式中罚项非负，去掉后得到

$$f(\boldsymbol{x}^{(t)}) \le f(\bar{\boldsymbol{x}}).$$

沿子列取极限，由 f 连续得 $f(\hat{\boldsymbol{x}}) \le f(\bar{\boldsymbol{x}})$。$\bar{\boldsymbol{x}}$ 是任取的可行点，所以 $\hat{\boldsymbol{x}}$ 全局最优。 ■

各条件的作用分得很清楚。可行集非空提供了比较点 $\bar{\boldsymbol{x}}$。下界把违规量和 ρ 联系起来。连续性保证极限可行，并让目标比较传到极限。“全局最小点”是证明的关键一步，局部解不能和远处的可行点比较。定理也不保证聚点存在：序列可能跑向无穷远，要排除这种情形，还需要类似水平集有界的条件。

去掉下界会怎样？考虑 $\min x^3$，$x \ge 0$，解是 $x^\star = 0$。罚函数在 $x < 0$ 时等于 $x^3 + \frac{\rho}{2}x^2$，$x \to -\infty$ 时趋于 $-\infty$，所以对任何 ρ 都没有全局最小点。图 22.4(a) 画出了这种情形：$x = 0$ 附近有一个局部的谷，越过左侧的小山就一路下降。原问题完全正常，罚问题却无下界。

近似解的极限　实际算法只能给出梯度小的点，通常连局部最小都不能保证。这时比较可行点的论证失效，能说的话变少，并且要多加条件。下面只写等式约束，记 $\boldsymbol{h}(\boldsymbol{x}) = (h_1(\boldsymbol{x}), \dots, h_p(\boldsymbol{x}))$，$\boldsymbol{J}(\boldsymbol{x}) \in \mathbb{R}^{p\times n}$ 是它的 Jacobian 矩阵。

定理 22.5 近似驻点的极限 设 f, h_j 连续可微，$\rho^{(t)} \to \infty$，并且

$$\|\nabla Q_{\rho^{(t)}}(\boldsymbol{x}^{(t)})\|_2 \le \omega^{(t)} \to 0. \tag{22.11}$$

设 $\hat{\boldsymbol{x}}$ 是 $\{\boldsymbol{x}^{(t)}\}$ 的聚点，则 $\hat{\boldsymbol{x}}$ 是 $\frac{1}{2}\|\boldsymbol{h}\|_2^2$ 的驻点。若进一步 $\hat{\boldsymbol{x}}$ 可行且 $\boldsymbol{J}(\hat{\boldsymbol{x}})$ 行满秩，则沿收敛到 $\hat{\boldsymbol{x}}$ 的子列有

$$\rho^{(t)}\boldsymbol{h}(\boldsymbol{x}^{(t)}) \to \hat{\boldsymbol{\nu}}, \qquad \nabla f(\hat{\boldsymbol{x}}) + \boldsymbol{J}(\hat{\boldsymbol{x}})^{\top}\hat{\boldsymbol{\nu}} = \boldsymbol{0}, \tag{22.12}$$

即 $(\hat{\boldsymbol{x}}, \hat{\boldsymbol{\nu}})$ 满足 KKT 条件。

证明 记 $\boldsymbol{e}^{(t)} = \nabla Q_{\rho^{(t)}}(\boldsymbol{x}^{(t)})$，$\boldsymbol{e}^{(t)} \to \boldsymbol{0}$。为简化写法，下面的量都沿子列取，并省略 $\boldsymbol{x}^{(t)}$ 的自变量。由梯度公式，

$$\nabla f + \rho^{(t)}\boldsymbol{J}^{\top}\boldsymbol{h} = \boldsymbol{e}^{(t)}.$$

两边除以 $\rho^{(t)}$，得到

$$\boldsymbol{J}^{\top}\boldsymbol{h} = \frac{\boldsymbol{e}^{(t)} - \nabla f}{\rho^{(t)}}.$$

右边的分子有界，分母趋于无穷，取极限得

$$\boldsymbol{J}(\hat{\boldsymbol{x}})^{\top}\boldsymbol{h}(\hat{\boldsymbol{x}}) = \boldsymbol{0}.$$

左边正是 $\frac{1}{2}\|\boldsymbol{h}\|_2^2$ 的梯度，第一个结论成立。

再设 $\hat{\boldsymbol{x}}$ 可行且 $\boldsymbol{J}(\hat{\boldsymbol{x}})$ 行满秩。$\boldsymbol{J}\boldsymbol{J}^{\top}$ 连续且极限可逆，所以 t 足够大时可逆。用 $\boldsymbol{J}$ 左乘第一个等式再求逆，解出

$$\rho^{(t)}\boldsymbol{h} = (\boldsymbol{J}\boldsymbol{J}^{\top})^{-1}\boldsymbol{J}\big(\boldsymbol{e}^{(t)} - \nabla f\big).$$

右边收敛，记极限为 $\hat{\boldsymbol{\nu}}$。把 $\rho^{(t)}\boldsymbol{h} \to \hat{\boldsymbol{\nu}}$ 代回第一个等式取极限，即得式 (22.12)。 ■

这个定理有两点值得注意。第一，$\hat{\boldsymbol{x}}$ 完全可能不可行，它只是约束残差平方的驻点。第二，定理的结论停在 KKT 点，和全局最优还差得远。

下面的例子显示第一点确实会发生。取

$$\min_{x} \ \frac{1}{2}x^2 \qquad \text{s.t.} \qquad h(x) = x^3 - 3x + 3 = 0.$$

三次方程只有一个实根 $x^\star \approx -2.104$，这也是唯一的可行点。h 在 $x = 1$ 处有局部极小值 $h(1) = 1$，所以 $\frac{1}{2}h^2$ 在这里有一个不可行的局部谷。图 22.4(b) 中绿点是 Q_3 在这个谷里的局部最小点。

取 $\rho = 10$ 和 $\rho = 100$，用二分法解 $Q_\rho'(x) = 0$，得到谷中的驻点分别是

$$x_{10} \approx 0.9835, \qquad x_{100} \approx 0.9983.$$

这两个点上 Q_ρ 的梯度为零，h 却约等于 1。放大 ρ 只会让点更靠近 $x = 1$，乘子估计 ρh 随之发散。乘子估计发散正是不可行极限的常见信号。

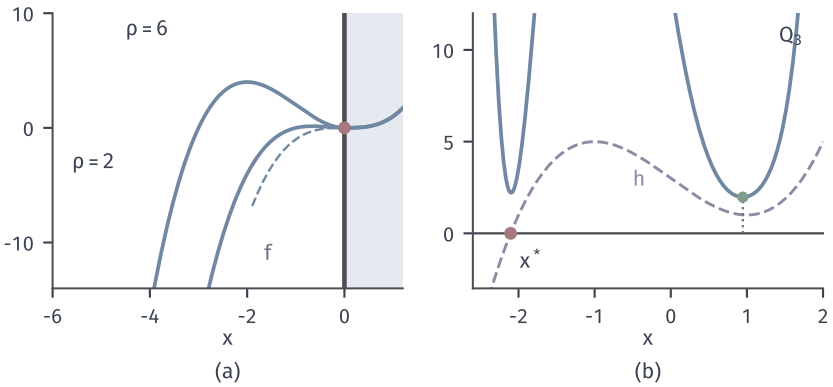


图 22.4 二次惩罚法的两种失败。(a)$\min x^3$，$x \ge 0$：蓝色实线是 $\rho = 2, 6$ 的罚函数，虚线是 f 的一段，浅蓝区域可行，红点是解；$x \to -\infty$ 时罚函数无下界。(b)$\min \frac{1}{2}x^2$，$h(x) = x^3 - 3x + 3 = 0$：紫色虚线是 h，蓝线是 Q_3，红点是唯一的可行点，绿点是不可行的局部最小点。

法向曲率的增长 剩下的问题是代价。对等式约束的罚函数求二阶导，得到

$$\nabla^2 Q_\rho = \nabla^2 f + \rho \sum_{j=1}^{p} h_j \nabla^2 h_j + \rho \boldsymbol{J}^\top \boldsymbol{J}. \tag{22.13}$$

由定理 22.5，ρh_j 在解附近接近有限的乘子，前两项之和接近 Lagrange 函数的 Hessian，大小不随 ρ 增长。第三项却正比于 ρ，它只在 $\boldsymbol{J}$ 的行空间里起作用，也就是约束的法方向上。

线性约束的二次目标可以把这件事算清楚。设目标和约束分别是

$$f(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^\top \boldsymbol{G}\boldsymbol{x} - \boldsymbol{d}^\top \boldsymbol{x}, \qquad \boldsymbol{h}(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} - \boldsymbol{b},$$

其中 $\boldsymbol{A} \in \mathbb{R}^{p \times n}$，$p < n$，$\boldsymbol{G}$ 半正定。此时 $\nabla^2 Q_\rho = \boldsymbol{G} + \rho \boldsymbol{A}^\top \boldsymbol{A}$ 不依赖 $\boldsymbol{x}$。

引理 22.6 罚函数 Hessian 的条件数 设 $\boldsymbol{A} \neq \boldsymbol{0}$，$\boldsymbol{Z}$ 的列是 $\operatorname{null}(\boldsymbol{A})$ 的一组标准正交基，矩阵 $\boldsymbol{Z}^\top \boldsymbol{G}\boldsymbol{Z}$ 正定，$\sigma_{\max}(\boldsymbol{A})$ 是 $\boldsymbol{A}$ 的最大奇异值。记 $\boldsymbol{H}_\rho = \boldsymbol{G} + \rho \boldsymbol{A}^\top \boldsymbol{A}$。当 $\boldsymbol{H}_\rho$ 正定时，有

$$\lambda_{\max}(\boldsymbol{H}_\rho) \ge \rho\, \sigma_{\max}(\boldsymbol{A})^2, \qquad \lambda_{\min}(\boldsymbol{H}_\rho) \le \lambda_{\min}(\boldsymbol{Z}^\top \boldsymbol{G}\boldsymbol{Z}), \tag{22.14}$$

于是条件数满足

$$\kappa(\boldsymbol{H}_\rho) \geq \frac{\rho\,\sigma_{\max}(\boldsymbol{A})^2}{\lambda_{\min}(\boldsymbol{Z}^\top \boldsymbol{G}\boldsymbol{Z})}. \tag{22.15}$$

证明 两个界都来自 Rayleigh 商。设 $\boldsymbol{u}$ 是 $\boldsymbol{A}$ 对应最大奇异值的单位右奇异向量。由 $\boldsymbol{G}$ 半正定，

$$\lambda_{\max}(\boldsymbol{H}_\rho) \geq \boldsymbol{u}^\top \boldsymbol{H}_\rho \boldsymbol{u} \geq \rho \|\boldsymbol{A}\boldsymbol{u}\|_2^2 = \rho\,\sigma_{\max}(\boldsymbol{A})^2.$$

再取单位向量 $\boldsymbol{w}$，使它达到 $\boldsymbol{Z}^\top \boldsymbol{G}\boldsymbol{Z}$ 的最小特征值，并令 $\boldsymbol{y} = \boldsymbol{Z}\boldsymbol{w}$。$\boldsymbol{y}$ 是单位向量且 $\boldsymbol{A}\boldsymbol{y} = \boldsymbol{0}$，所以罚项消失：

$$\lambda_{\min}(\boldsymbol{H}_\rho) \leq \boldsymbol{y}^\top \boldsymbol{H}_\rho \boldsymbol{y} = \boldsymbol{w}^\top \boldsymbol{Z}^\top \boldsymbol{G}\boldsymbol{Z}\boldsymbol{w} = \lambda_{\min}(\boldsymbol{Z}^\top \boldsymbol{G}\boldsymbol{Z}).$$

两式相除，即得式 (22.15)。 ■

几何上看，$\boldsymbol{H}_\rho$ 把空间分成两部分：沿约束的切方向，曲率不受 ρ 影响；沿法方向，曲率约正比于 ρ。这就是图 22.2里等高线越来越狭长的原因。

二元例中 $\boldsymbol{G} = \mathrm{diag}(1, 3)$，$\boldsymbol{A} = (1, 1)$，$\sigma_{\max}(\boldsymbol{A})^2 = 2$。切方向是单位向量 $(1, -1)/\sqrt{2}$，切向曲率是

$$\boldsymbol{Z}^\top \boldsymbol{G}\boldsymbol{Z} = \frac{1 + 3}{2} = 2.$$

下表给出 $\boldsymbol{H}_\rho$ 的实际特征值，最小特征值逐渐接近切向曲率 2，最大特征值约等于 2ρ。

ρ	$\lambda_{\min}$	$\lambda_{\max}$	κ
1.5	1.697	5.303	3.1
15	1.967	32.03	16.3
150	1.997	302.0	151.3
1500	2.000	3002	1501

表 22.1 二元例中罚函数 Hessian 的特征值与条件数。

图 22.5把精度和代价放在一起。(a) 是违规量，ρ 放大十倍，违规量缩小十倍。(b) 是条件数和梯度步数，ρ 放大十倍，条件数也放大十倍，每轮的梯度步数增长的倍数相近。

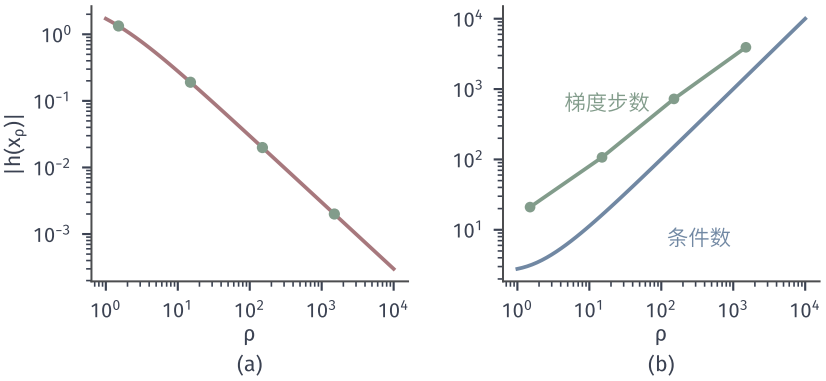


图 22.5 二元例中罚参数的收益与代价，双对数坐标。(a) 精确罚解的违规量 $12/(3+4\rho)$，绿点是 $\rho = 1.5, 15, 150, 1500$。(b) 蓝线是 $\nabla^2 Q_\rho$ 的条件数，绿线是热启动的梯度法（步长 $1/L$，梯度容差 10^{-3}）在各轮用的步数。

梯度法的困难可以直接看到。图 22.6从同一点出发各走 25 步。$\rho = 1.5$ 时点很快到达最小点附近；$\rho = 15$ 时第一步几乎只修正法向，点落到直线旁边，然后沿狭长山谷缓慢爬行，25 步还没有走到。步长受最大曲率限制，只能取 $1/L \approx 1/(2\rho)$，切方向每步却只能修正很小一部分。

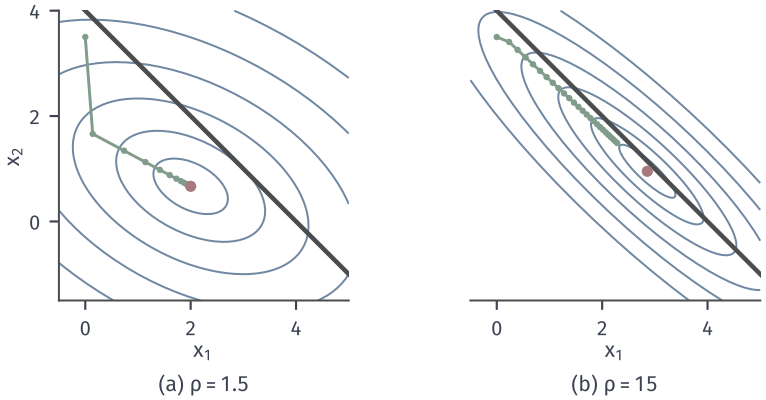


图 22.6 梯度法在 Q_ρ 上的路径，起点 $(0, 3.5)$，步长 $1/L$，共 25 步。蓝线是 Q_ρ 的等高线，深灰直线是约束，绿色折线是迭代路径，红点是 Q_ρ 的最小点。(a)$\rho = 1.5$，几步后接近最小点。(b)$\rho = 15$，先快速到达山谷，再沿谷底缓慢前进。

病态是否致命，取决于内层用什么方法。Newton 法不怕目标的简单伸缩，但线性方程组 $\boldsymbol{H}_\rho \boldsymbol{d} = -\nabla Q_\rho$ 的系数矩阵本身条件数很差。引入 $\boldsymbol{w} = \rho \boldsymbol{A}\boldsymbol{d}$，可以把它等价地写成

$$\begin{pmatrix} \boldsymbol{G} & \boldsymbol{A}^{\top} \\ \boldsymbol{A} & -\rho^{-1}\boldsymbol{I} \end{pmatrix} \begin{pmatrix} \boldsymbol{d} \\ \boldsymbol{w} \end{pmatrix} = \begin{pmatrix} -\nabla Q_\rho \\ \boldsymbol{0} \end{pmatrix}. \tag{22.16}$$

$\rho \to \infty$ 时这个系统趋于一个不含大数的 KKT 矩阵，数值上稳定得多。这个变换改善的是线性代数的数值误差，并不减少外层要解的问题个数。一阶方法没有这种办法。第 22.4节要给出另一条出路：不把 ρ 推向无穷。

22.1 二次惩罚法
22.2 精确惩罚法
22.2.1 精确性的条件
22.2.2 非光滑罚问题的求解
22.3 对偶上升
22.4 增广 Lagrange 法（ALM）
22.5 交替方向乘子法（ADMM）
22.6 方法比较与计算成本
22.7 本章小结

22.2 精确惩罚法

上一节的二次罚必须把 ρ 推向无穷，原因就在罚项本身：平方函数在零点的斜率是零。可行边界上，罚项完全没有回推的力，目标只要有一点斜率，点就会越过边界，直到弹簧被拉长。这就需要回答：换一种在边界上就有斜率的罚项，有限的 ρ 能否直接得到原问题的解？

一次罚函数　把平方换成绝对值和正部本身，在零点就有了尖角：

定义 22.7　一次罚函数　对问题 (22.3)和 $\rho > 0$，记总违规量

$$V(\boldsymbol{x}) = \sum_{i=1}^{m} [g_i(\boldsymbol{x})]_+ + \sum_{j=1}^{p} |h_j(\boldsymbol{x})|, \tag{22.17}$$

称

$$E_\rho(\boldsymbol{x}) = f(\boldsymbol{x}) + \rho V(\boldsymbol{x}) \tag{22.18}$$

为**一次罚函数**（ℓ_1 penalty function）。若存在有限的 ρ，使 E_ρ 的最小点就是原问题的最小点，就称这个罚函数是**精确罚函数**（exact penalty function）。

“精确”说的是两个问题的解之间的对应关系。它并不表示数值上已经把子问题解到了机器精度，也不表示算法可以一步得到解。

示例 22.8　一维例的一次罚　式 (22.2)的一次罚函数是

$$E_\rho(x) = x + \rho[1 - x]_+.$$

$x > 1$ 时斜率是 1，$x < 1$ 时斜率是 $1 - \rho$。结果按 ρ 分成三种情形：

- $\rho < 1$ 时，$x < 1$ 的一侧斜率为正，$x \to -\infty$ 时 $E_\rho \to -\infty$，没有最小点；
- $\rho = 1$ 时，$x \le 1$ 的整条射线上 $E_\rho \equiv 1$，最小点集合比原问题的解大；
- $\rho > 1$ 时，E_ρ 在 $x = 1$ 处由负斜率转为正斜率，$x = 1$ 是唯一最小点。

门槛恰好是 $\lambda^\star = 1$。

图 22.7(a) 画出这三种情形。尖角的作用从图上一眼可见：只要左边的斜率足够陡，最低点就被“钉”在尖角上，不需要 ρ 继续增大。这和一元绝对值函数的最小点停在零点，是同一种机制。

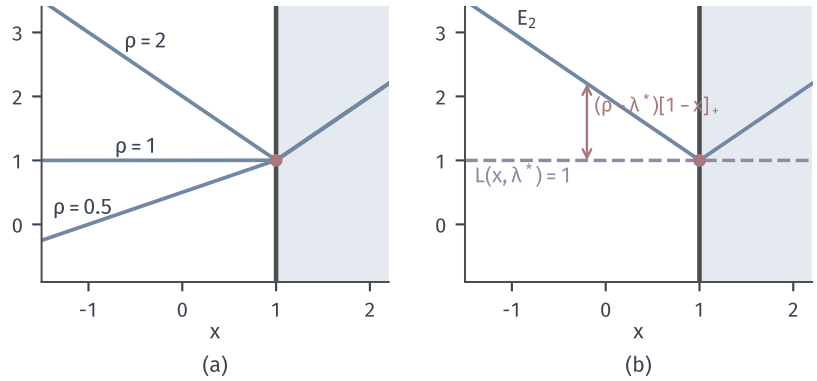


图 22.7　一维例的一次罚函数。浅蓝区域可行，深灰竖线是约束边界，红点是解 $x^\star = 1$。(a) 蓝线是 $\rho = 0.5, 1, 2$ 的 E_ρ：$\rho < 1$ 无下界，$\rho = 1$ 左侧水平，$\rho > 1$ 最小点就是 $x^\star$。(b) 蓝线是 E_2，紫色虚线是 Lagrange 函数 $\mathcal{L}(x, \lambda^\star) \equiv 1$，$E_2$ 在它上方，红色箭头是两者之差。

二元例的比较　式 (22.1)的一次罚函数是

$$E_\rho(\boldsymbol{x}) = \frac{1}{2}x_1^2 + \frac{3}{2}x_2^2 + \rho|x_1 + x_2 - 4|.$$

最优性条件是存在 $\xi \in \partial|\cdot|(h(\boldsymbol{x}))$，使 $\boldsymbol{x}$ 满足

$$x_1 + \rho\xi = 0, \qquad 3x_2 + \rho\xi = 0.$$

其中 $\xi = \operatorname{sign}(h)$（当 $h \neq 0$），$\xi \in [-1, 1]$（当 $h = 0$）。先假设解落在 $h < 0$ 的一侧，此时 $\xi = -1$，解出

$$\boldsymbol{x} = \rho\Big(1, \frac{1}{3}\Big).$$

$h < 0$ 要求 $\frac{4}{3}\rho - 4 < 0$，即 $\rho < 3$。当 $\rho \geq 3$ 时，取 $h = 0$，也就是 $\boldsymbol{x} = (3, 1)$，由第一个方程得

$$\xi = -\frac{3}{\rho} \in [-1, 0).$$

所以 $\rho \geq 3$ 时解就是 $\boldsymbol{x}^\star$，门槛是 $|\nu^\star| = 3$。

图 22.8把两种罚放在同一张图里。二次罚的 $x_1(\rho)$ 永远在逼近 3 而到不了；一次罚先沿直线上升，在 $\rho = 3$ 处到达 3，此后不再变化，违规量恰好为零。代价是 $\rho < 3$ 时一次罚的违规量可能更大，并且 E_ρ 在解处不可微。

22.1 二次惩罚法
22.2 精确惩罚法
22.2.1 精确性的条件
22.2.2 非光滑罚问题的求解
22.3 对偶上升
22.4 增广 Lagrange 法（ALM）
22.5 交替方向乘子法（ADMM）
22.6 方法比较与计算成本
22.7 本章小结

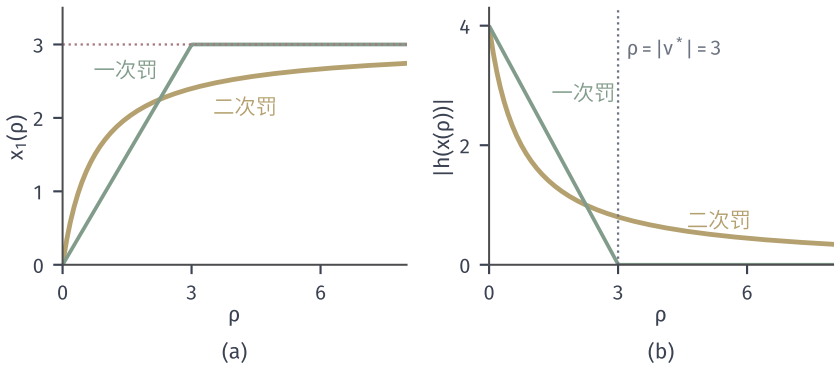


图 22.8 二元例中两种罚函数的解随 ρ 变化。黄线是二次罚，绿线是一次罚，(a) 中红色点线是 $x_1^\star = 3$。(a) 第一个坐标：二次罚只能渐近，一次罚在 $\rho = 3$ 到达并停住。(b) 违规量：一次罚在 $\rho \geq 3$ 时恰为零，门槛等于 $|\nu^\star|$。

	二次罚 Q_ρ	一次罚 E_ρ
边界上的斜率	零	非零
有限 ρ 的解	一般不可行	超过门槛后可行
光滑性	一阶连续可微	边界上不可微
ρ 的取法	必须趋于无穷	只需超过乘子门槛
内层困难	法向曲率增长	解处有尖角

表 22.2 二次罚与一次罚的对照。二次罚以病态换取光滑，一次罚以不可微换取有限的罚参数。

22.2.1 精确性的条件

门槛和乘子的关系不是例子的巧合。下面要把它写成定理，并分清全局和局部两个层次。

全局精确性 回忆第 18章的记号。Lagrange 函数是

$$\mathcal{L}(\boldsymbol{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}) = f(\boldsymbol{x}) + \sum_{i=1}^{m} \lambda_i g_i(\boldsymbol{x}) + \sum_{j=1}^{p} \nu_j h_j(\boldsymbol{x}),$$

对偶函数 q 是 $\mathcal{L}$ 对 $\boldsymbol{x}$ 的下确界。弱对偶说 $\boldsymbol{\lambda} \geq \mathbf{0}$ 时 $q(\boldsymbol{\lambda}, \boldsymbol{\nu}) \leq f^\star$；强对偶说存在 $(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 使等号成立。这个下界和一次罚函数放在一起，就是图 22.7(b) 的画面：$\mathcal{L}(x, \lambda^\star)$ 是整条水平线，E_ρ 处处在它上方。

定理 22.9　一次罚的全局精确性　设原问题的最优解 $\boldsymbol{x}^\star$ 存在，对偶问题的最优解 $(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 存在，且强对偶成立，$q(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) = f^\star$。若

$$\rho > \max\Big\{\max_i \lambda_i^\star,\ \max_j |\nu_j^\star|\Big\}, \tag{22.19}$$

则 E_ρ 的全局最小点集合恰好等于原问题的全局最优解集合，且对所有 $\boldsymbol{x}$ 有

$$E_\rho(\boldsymbol{x}) \geq f^\star + \delta V(\boldsymbol{x}), \tag{22.20}$$

其中 $\delta > 0$ 是 ρ 与门槛之差。

证明　记门槛为 ρ_0，$\delta = \rho - \rho_0 > 0$。先建立式 (22.20)。由 $\lambda_i^\star \geq 0$ 和 $g_i \leq [g_i]_+$，有

$$\lambda_i^\star g_i(\boldsymbol{x}) \leq \lambda_i^\star [g_i(\boldsymbol{x})]_+ \leq \rho_0 [g_i(\boldsymbol{x})]_+.$$

对等式项同样有

$$\nu_j^\star h_j(\boldsymbol{x}) \leq |\nu_j^\star||h_j(\boldsymbol{x})| \leq \rho_0 |h_j(\boldsymbol{x})|.$$

把这些不等式对 i, j 求和，得到

$$\sum_i \lambda_i^\star g_i(\boldsymbol{x}) + \sum_j \nu_j^\star h_j(\boldsymbol{x}) \leq \rho_0 V(\boldsymbol{x}).$$

于是

$$\begin{aligned} E_\rho(\boldsymbol{x}) &= f(\boldsymbol{x}) + \rho_0 V(\boldsymbol{x}) + \delta V(\boldsymbol{x}) \\ &\geq \mathcal{L}(\boldsymbol{x}, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) + \delta V(\boldsymbol{x}) \\ &\geq q(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) + \delta V(\boldsymbol{x}). \end{aligned}$$

由强对偶，最后一式等于 $f^\star + \delta V(\boldsymbol{x})$，这就是式 (22.20)。

再看最小点集合。任一原问题最优解 $\boldsymbol{x}^\star$ 满足 $V(\boldsymbol{x}^\star) = 0$，$E_\rho(\boldsymbol{x}^\star) = f^\star$，由下界知它是 E_ρ 的全局最小点，且 E_ρ 的最小值是 $f^\star$。

反过来，设 $\bar{\boldsymbol{x}}$ 是 E_ρ 的全局最小点，则 $E_\rho(\bar{\boldsymbol{x}}) = f^\star$。代入下界得 $\delta V(\bar{\boldsymbol{x}}) \leq 0$，所以 $V(\bar{\boldsymbol{x}}) = 0$，$\bar{\boldsymbol{x}}$ 可行。此时 $f(\bar{\boldsymbol{x}}) = E_\rho(\bar{\boldsymbol{x}}) = f^\star$，它是原问题的最优解。 ■

式 (22.19)中的门槛用的是最大绝对分量，因为总违规量是 ℓ_1 形式，两者互为对偶范数。门槛可以按任一组最优乘子计算，最优乘子不唯一时，取能使门槛最小的一组。

证明里没有用到凸性，全部负担都在强对偶上。对一般的非凸问题，强对偶很少成立，所以全局精确性主要是凸问题的结论；第 18章给出的 Slater 条件是常用的充分条件。

严格不等号也不能省。一维例中 $\rho = 1$ 恰好等于门槛，E_1 的最小点是整条射线 $(-\infty, 1]$，原问题的解只是其中一点。此时 $\delta = 0$，下界 (22.20)里违规量的系数消失，最后一步推不出可行。

对偶解不存在时　去掉“对偶最优解存在”，结论会彻底失败。考虑

$$\min_{x} \; x \qquad \text{s.t.} \qquad x^2 \le 0.$$

可行集只有 $\{0\}$，$x^\star = 0$。这是凸问题，$q(\lambda) = -1/(4\lambda)$，$\lambda \to \infty$ 时趋于 $0 = f^\star$，但上确界取不到，不存在有限的最优乘子。它的一次罚是 $E_\rho(x) = x + \rho x^2$，唯一最小点是

$$x_\rho = -\frac{1}{2\rho} \neq 0.$$

对每个有限的 ρ，最小点都不可行，ρ 必须趋于无穷。这里约束的梯度在解处是零，违规量 x^2 在解处光滑，根本没有尖角。可见一次罚的尖角要靠约束的梯度才能起作用。

局部精确性　非凸问题用不上强对偶，可以只问局部：$\boldsymbol{x}^\star$ 是否是 E_ρ 的局部最小点。局部分析有两条路线。一条看约束集的几何，要求违规量控制到可行集的距离；另一条看 KKT 条件和曲率。

第一条路线的条件是**局部误差界**（local error bound）：存在 $\tau > 0$ 和 $\boldsymbol{x}^\star$ 的邻域，使邻域内的 $\boldsymbol{x}$ 满足

$$\operatorname{dist}(\boldsymbol{x}, \boldsymbol{C}) \le \tau V(\boldsymbol{x}). \tag{22.21}$$

它的意思是，违规量小就真的离可行集近，不会出现违规量几乎为零、点却还很远的情况。线性约束时误差界在整个空间成立，这是 Hoffman 界。对光滑约束，它在 Mangasarian–Fromovitz 约束资格下成立，证明需要用到非线性系统的度量正则性，篇幅较长，这里只使用结论。

第二条路线要用到二阶条件。在 KKT 点 $(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 处，临界方向 $\boldsymbol{d}$ 满足

$$\nabla h_j(\boldsymbol{x}^\star)^{\top} \boldsymbol{d} = 0, \qquad \begin{cases} \nabla g_i(\boldsymbol{x}^\star)^{\top} \boldsymbol{d} = 0, & g_i(\boldsymbol{x}^\star) = 0,\ \lambda_i^\star > 0, \\ \nabla g_i(\boldsymbol{x}^\star)^{\top} \boldsymbol{d} \le 0, & g_i(\boldsymbol{x}^\star) = 0,\ \lambda_i^\star = 0. \end{cases} \tag{22.22}$$

二阶充分条件要求 Lagrange 函数在 KKT 点处的 Hessian 沿每个非零临界方向 $\boldsymbol{d}$ 都有正曲率：

$$\boldsymbol{d}^{\top} \nabla^2_{\boldsymbol{x}\boldsymbol{x}} \mathcal{L}(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) \boldsymbol{d} > 0.$$

它的含义第 17章已经建立。

定理 22.10　一次罚的局部精确性　设 $\boldsymbol{x}^\star$ 是可行点。

1. 设 $\boldsymbol{C}$ 是闭集，$\boldsymbol{x}^\star$ 是 f 在 $\boldsymbol{C}$ 上的局部最小点，f 在 $\boldsymbol{x}^\star$ 的邻域内 G-Lipschitz，且局部误差界 (22.21)成立。若 $\rho > G\tau$，则 $\boldsymbol{x}^\star$ 是 E_ρ 的局部最小点。
2. 设 f, g_i, h_j 二阶连续可微，$(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 是 KKT 点并满足二阶充分条件。若 ρ 满足式 (22.19)，则 $\boldsymbol{x}^\star$ 是 E_ρ 的严格局部最小点。

证明　先证第一部分。取充分小的 $r > 0$，使 $\|\boldsymbol{x} - \boldsymbol{x}^\star\|_2 \le r$ 时误差界成立，并使 $\boldsymbol{x}^\star$ 在半径 $2r$ 的球内是 f 在 $\boldsymbol{C}$ 上的最小点，f 在该球内 G-Lipschitz。

任取这样的 $\boldsymbol{x}$，设 $\boldsymbol{y}$ 是 $\boldsymbol{x}$ 在闭集 $\boldsymbol{C}$ 上的一个最近点。$\boldsymbol{x}^\star$ 也在 $\boldsymbol{C}$ 中，所以

$$\|\boldsymbol{x} - \boldsymbol{y}\|_2 \le \|\boldsymbol{x} - \boldsymbol{x}^\star\|_2 \le r.$$

由三角不等式，$\boldsymbol{y}$ 在半径 $2r$ 的球内。于是

$$f(\boldsymbol{x}) \ge f(\boldsymbol{y}) - G\|\boldsymbol{x} - \boldsymbol{y}\|_2 \ge f(\boldsymbol{x}^\star) - G\tau V(\boldsymbol{x}).$$

由此得

$$E_\rho(\boldsymbol{x}) \ge f(\boldsymbol{x}^\star) + (\rho - G\tau) V(\boldsymbol{x}) \ge E_\rho(\boldsymbol{x}^\star).$$

再证第二部分，用反证法。设 $\boldsymbol{x}^\star$ 不是严格局部最小点，则存在 $\boldsymbol{x}^{(k)} \to \boldsymbol{x}^\star$，$\boldsymbol{x}^{(k)} \ne \boldsymbol{x}^\star$，$E_\rho(\boldsymbol{x}^{(k)}) \le f(\boldsymbol{x}^\star)$。记 $\boldsymbol{d}^{(k)} = \boldsymbol{x}^{(k)} - \boldsymbol{x}^\star$，取子列使单位向量 $\boldsymbol{d}^{(k)}/\|\boldsymbol{d}^{(k)}\|_2$ 收敛到 $\boldsymbol{d}$。

记 ρ_0 为式 (22.19)的右端，$\delta = \rho - \rho_0 > 0$，$[a]_- = \max\{-a, 0\}$。对单个不等式约束，$a = g_i(\boldsymbol{x}^{(k)})$ 时有

$$\rho [a]_+ - \lambda_i^\star a \ge \delta [a]_+ + \lambda_i^\star [a]_-.$$

22.1 二次惩罚法
22.2 精确惩罚法
22.2.1 精确性的条件
22.2.2 非光滑罚问题的求解
22.3 对偶上升
22.4 增广 Lagrange 法（ALM）
22.5 交替方向乘子法（ADMM）
22.6 方法比较与计算成本
22.7 本章小结

这个不等式分两种情形验证：$a>0$ 时左边等于 $(\rho-\lambda_i^\star)a\ge\delta a$，$a\le 0$ 时左边等于 $\lambda_i^\star|a|$。等式项类似，

$$\rho|h_j|-\nu_j^\star h_j\ge\delta|h_j|.$$

把它们加起来，并用 $\mathcal{L}^\star$ 表示乘子固定为 $(\boldsymbol{\lambda}^\star,\boldsymbol{\nu}^\star)$ 的 Lagrange 函数，得到

$$E_\rho(\boldsymbol{x}^{(k)})\ge\mathcal{L}^\star(\boldsymbol{x}^{(k)})+\delta V(\boldsymbol{x}^{(k)})+\sum_i\lambda_i^\star[g_i(\boldsymbol{x}^{(k)})]_-.$$

KKT 条件给出 $\mathcal{L}^\star(\boldsymbol{x}^\star)=f(\boldsymbol{x}^\star)$ 和 $\nabla\mathcal{L}^\star(\boldsymbol{x}^\star)=\mathbf{0}$。作二阶展开，记 $\boldsymbol{W}=\nabla^2\mathcal{L}^\star(\boldsymbol{x}^\star)$，则

$$\mathcal{L}^\star(\boldsymbol{x}^{(k)})=f(\boldsymbol{x}^\star)+\frac{1}{2}(\boldsymbol{d}^{(k)})^{\top}\boldsymbol{W}\boldsymbol{d}^{(k)}+o(\|\boldsymbol{d}^{(k)}\|_2^2).$$

结合 $E_\rho(\boldsymbol{x}^{(k)})\le f(\boldsymbol{x}^\star)$，得到

$$\delta V(\boldsymbol{x}^{(k)})+\sum_i\lambda_i^\star[g_i(\boldsymbol{x}^{(k)})]_-\le-\frac{1}{2}(\boldsymbol{d}^{(k)})^{\top}\boldsymbol{W}\boldsymbol{d}^{(k)}+o(\|\boldsymbol{d}^{(k)}\|_2^2).$$

右边是 $O(\|\boldsymbol{d}^{(k)}\|_2^2)$，所以左边每一项都是这个量级。展开 $h_j(\boldsymbol{x}^{(k)})$，除以 $\|\boldsymbol{d}^{(k)}\|_2$ 取极限，由 $|h_j|=O(\|\boldsymbol{d}^{(k)}\|_2^2)$ 得 $\nabla h_j(\boldsymbol{x}^\star)^{\top}\boldsymbol{d}=0$。对活动的 g_i，$[g_i]_+=O(\|\boldsymbol{d}^{(k)}\|_2^2)$ 给出 $\nabla g_i(\boldsymbol{x}^\star)^{\top}\boldsymbol{d}\le 0$；当 $\lambda_i^\star>0$ 时，$[g_i]_-$ 也是这个量级，于是等号成立。所以 $\boldsymbol{d}$ 是非零临界方向。

最后，上式左边非负。两边除以 $\|\boldsymbol{d}^{(k)}\|_2^2$ 取极限，得到 $\boldsymbol{d}^{\top}\boldsymbol{W}\boldsymbol{d}\le 0$，与二阶充分条件矛盾。 ■

两部分的结论都只说 $\boldsymbol{x}^\star$ 附近的事。局部精确不等于全局精确，例如 $\min -x^4$，约束 $x=0$。此时 $\nu^\star=0$，门槛是零，对任何 $\rho>0$，$x=0$ 都是 $E_\rho(x)=-x^4+\rho|x|$ 的严格局部最小点，而 $x\to\infty$ 时 $E_\rho\to-\infty$。

22.2.2 非光滑罚问题的求解

有了精确性，还要回答怎么解 E_ρ。它的尖角恰好在解的位置上，光滑方法在这里不能直接使用。第 11章的工具可以逐一套用，但每种工具都要先核对问题的结构。

次梯度与最优性　设 f 和 h_j 可微，问题是凸的。$0 \in \partial E_\rho(\boldsymbol{x})$ 写开来，就是存在 $\xi_j \in \partial|\cdot|(h_j(\boldsymbol{x}))$，使

$$\nabla f(\boldsymbol{x}) + \sum_{j=1}^{p} \rho \xi_j \nabla h_j(\boldsymbol{x}) = \mathbf{0}. \tag{22.23}$$

和 KKT 的驻定方程比较，$\nu_j = \rho\xi_j$ 就是乘子估计。ξ_j 落在 $[-1,1]$ 内，$|\nu_j| \le \rho$。如果解上某条约束的 $|\xi_j| = 1$ 且仍然违规，说明罚参数不够大，或者问题本身不可行。

次梯度法只需要这些 ξ_j，但第 11章已经看到，步长固定时点会在尖角附近反复跳动，收敛很慢。图 22.9里的黄线就是这种行为，它在约束直线两侧来回穿越，几乎每一步都不可行。

邻近梯度　若把光滑部分 f 留给梯度步，把 ρV 留给邻近步，就是第 11章的邻近梯度法。关键在于邻近映射能否算出。对二元例，设 $\boldsymbol{a} = (1,1)$，$\tau = \alpha\rho$，要解的子问题是

$$\boldsymbol{p} = \arg\min_{\boldsymbol{x}} \ \frac{1}{2}\|\boldsymbol{x} - \boldsymbol{v}\|_2^2 + \tau|\boldsymbol{a}^{\top}\boldsymbol{x} - 4|. \tag{22.24}$$

由最优性条件，存在 $|\cdot|$ 在 $\boldsymbol{a}^{\top}\boldsymbol{p} - 4$ 处的次梯度 ξ，使 $\boldsymbol{p} = \boldsymbol{v} - \tau\xi\boldsymbol{a}$。两边与 $\boldsymbol{a}$ 作内积，得到

$$\boldsymbol{a}^{\top}\boldsymbol{p} - 4 = \boldsymbol{a}^{\top}\boldsymbol{v} - 4 - \tau\xi\|\boldsymbol{a}\|_2^2.$$

令 $s = (\boldsymbol{a}^{\top}\boldsymbol{v} - 4)/\|\boldsymbol{a}\|_2^2$。若 $|s| \le \tau$，取 $\xi = s/\tau$ 可使约束恰好满足，这时 $\boldsymbol{p}$ 就是 $\boldsymbol{v}$ 到直线的投影。若 $|s| > \tau$，约束仍然违规，$\xi = \operatorname{sign}(s)$。两种情形合写成

$$\boldsymbol{p} = \boldsymbol{v} - \operatorname{clip}_{\tau}(s)\,\boldsymbol{a}, \qquad \operatorname{clip}_{\tau}(s) = \max\{-\tau, \min\{s, \tau\}\}. \tag{22.25}$$

下面用这个公式走几步。取 $\rho = 4$，它大于门槛 3。f 的光滑常数是 3，步长 $\alpha = 1/3$，所以 $\tau = 4/3$。迭代 $\boldsymbol{v} = \boldsymbol{x} - \alpha\nabla f(\boldsymbol{x})$ 的两个坐标是 $\frac{2}{3}x_1$ 和 0：

$$\boldsymbol{v} = \Big(x_1 - \frac{1}{3}x_1,\ x_2 - x_2\Big) = \Big(\frac{2}{3}x_1,\ 0\Big).$$

从 $\boldsymbol{x}^{(0)} = (0,0)$ 出发，$\boldsymbol{v} = (0,0)$，$s = -2$，被截断到 $-\tau$，得到

$$\boldsymbol{x}^{(1)} = \Big(\frac{4}{3},\ \frac{4}{3}\Big).$$

第二步 $\boldsymbol{v} = (\frac{8}{9}, 0)$，$s = -\frac{14}{9}$，仍被截断，得到

$$\boldsymbol{x}^{(2)} = \Big(\frac{20}{9},\ \frac{4}{3}\Big).$$

第三步 $\boldsymbol{v}=(\frac{40}{27},0)$，$s=-\frac{34}{27}$，这次 $|s|<\tau$，投影到直线上，得到

$$\boldsymbol{x}^{(3)}=\Big(\frac{74}{27},\frac{34}{27}\Big),\qquad h(\boldsymbol{x}^{(3)})=0.$$

此后每步都留在直线上,并沿直线逼近 $(3,1)$。乘子估计可以从 $\nu=\rho\xi=s/\alpha$ 读出，第三步是 $-\frac{34}{9}\approx-3.78$，到解处变为 -3。图 22.9的绿线就是这条路径：有限步后恰好可行，这是尖角带来的好处，二次罚做不到。

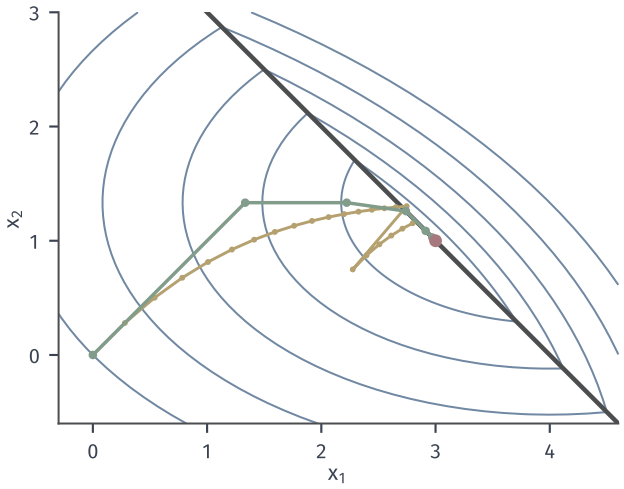


图 22.9　二元例中一次罚 E_4 的两种解法，蓝线是等高线，深灰直线是约束。绿线是邻近梯度法（步长 1/3），第三步落到直线上，此后沿直线走向红点。黄线是次梯度法（步长 0.07），在直线两侧反复穿越，停留在解附近的一个小区域。

一般约束的处理　这个闭式解依赖约束只有一条且是线性的。若 $\boldsymbol{h}(\boldsymbol{x})=\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}$ 有多行，$\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|_1$ 的邻近映射本身就要解一个优化问题；若 h_j 非线性，一般没有闭式解。

常用的办法是第 11章的局部模型：在当前点把约束线性化，保留绝对值，再加上二次距离项，解

$$\min_{\boldsymbol{d}}\ \nabla f(\boldsymbol{x})^{\top}\boldsymbol{d}+\frac{1}{2\alpha}\|\boldsymbol{d}\|_2^2+\rho\sum_{j=1}^{p}\big|h_j(\boldsymbol{x})+\nabla h_j(\boldsymbol{x})^{\top}\boldsymbol{d}\big|. \tag{22.26}$$

引入非负松弛变量把绝对值拆开，这是一个凸二次规划。模型是否可信要用真实的 E_ρ 检验，也就是比较预测下降和实际下降，第 23章会回到这一点。

解 E_ρ 结束时，还需要回到原问题做两项检查。第一，算出原约束的违规量 $V(\boldsymbol{x})$，罚目标下降了不代表违规量已经降到容差以下。第二，核对 ρ 是否大于乘子估计的最大绝对分量。如果 $|\xi_j|$ 贴着 1，定理 22.9的条件就没有满足，应当增大 ρ 再解。数值上的 ρ 也不宜太大，否则目标的信息在罚项面前被淹没，迭代会贴着约束走得很慢。

22.3 对偶上升

22.1 二次惩罚法
22.2 精确惩罚法
22.3 对偶上升
22.3.1 残差与乘子更新
22.3.2 对偶分解与原始恢复
22.4 增广 Lagrange 法（ALM）
22.5 交替方向乘子法（ADMM）
22.6 方法比较与计算成本
22.7 本章小结

二次罚的解满足 $\rho h(\boldsymbol{x}_\rho) \to \nu^\star$，一次罚的门槛也是乘子。两节下来，真正需要的量似乎一直是乘子，罚项只是在间接地把它制造出来。本节换一个问题：如果直接把乘子当作价格来调整，不加任何罚项，能走多远？

价格让碗倾斜 先回到工厂的例子。总部报出乘子 ν，相当于对约束 $x_1 + x_2 - 4$ 计价，两家工厂面对的是 Lagrange 函数：

$$\mathcal{L}(\boldsymbol{x}, \nu) = \frac{1}{2}x_1^2 + \frac{3}{2}x_2^2 + \nu(x_1 + x_2 - 4).$$

固定 ν，这是一个没有约束的严格凸二次函数。令梯度为零，得到

$$\boldsymbol{x}(\nu) = -\nu\Big(1, \frac{1}{3}\Big). \tag{22.27}$$

写成 $p = -\nu$ 更好读：单价 p 越高，工厂产量越高，$x_1 = p$，$x_2 = p/3$。线性项 $\nu(x_1 + x_2)$ 不改变碗的形状，只把碗底平移。

图 22.10是平移的过程。$\nu = 0$ 时碗底在原点，离约束很远。$\nu = -2.4$ 时碗底靠近直线，还差一点。$\nu = -3$ 时碗底恰好落在约束上的红点处，也就是原问题的解。这时不用任何约束，无约束最小点自己满足了约束。

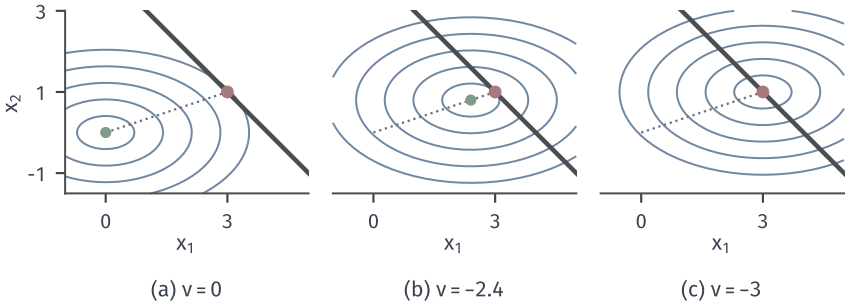


图 22.10 乘子使 Lagrange 函数的碗底平移。蓝线是 $\mathcal{L}(\cdot, \nu)$ 的等高线，深灰直线是约束，绿点是 $\boldsymbol{x}(\nu)$，红点是解 $(3, 1)$，灰色点线是碗底走过的射线。(c) 中 $\nu = \nu^\star = -3$，碗底恰好落在约束上。

把 $\boldsymbol{x}(\nu)$ 代回，得到这个例子的对偶函数，它是 Lagrange 函数在 $\boldsymbol{x}$ 上的最小值：

$$q(\nu) = \frac{1}{2}\nu^2 + \frac{1}{6}\nu^2 + \nu\Big(-\frac{4}{3}\nu - 4\Big).$$

合并同类项，结果是

$$q(\nu) = -\frac{2}{3}\nu^2 - 4\nu. \tag{22.28}$$

由弱对偶，每个 $q(\nu)$ 都是 $f^\star$ 的下界。这个二次函数在 $\nu^\star = -3$ 处达到最大值 $q(-3) = 6 = f^\star$。

22.1 二次惩罚法
22.2 精确惩罚法
22.3 对偶上升
22.3.1 残差与乘子更新
22.3.2 对偶分解与原始恢复
22.4 增广 Lagrange 法（ALM）
22.5 交替方向乘子法（ADMM）
22.6 方法比较与计算成本
22.7 本章小结

一般情形 一般问题中，固定 $(\boldsymbol{\lambda},\boldsymbol{\nu})$，要解的是 Lagrange 子问题。第 18章定义了对偶函数，这里允许把简单的集合 $\boldsymbol{X}$（如整个空间或盒子）保留在子问题里：

$$q(\boldsymbol{\lambda},\boldsymbol{\nu}) = \inf_{\boldsymbol{x}\in\boldsymbol{X}} \mathcal{L}(\boldsymbol{x},\boldsymbol{\lambda},\boldsymbol{\nu}). \tag{22.29}$$

它是一族关于 $(\boldsymbol{\lambda},\boldsymbol{\nu})$ 的线性函数的下确界，因此总是凹的，这与原问题是否凸无关。求解对偶问题就是在 $\boldsymbol{\lambda}\geq\mathbf{0}$ 上最大化这个凹函数。

22.3.1 残差与乘子更新

要上升就要知道方向。这里的好消息是：解完 Lagrange 子问题，约束残差就是现成的上升信息。

残差是超梯度 二元例的导数是 $q'(\nu) = -\frac{4}{3}\nu - 4$，把式 (22.27)代入，这恰好等于 $h(\boldsymbol{x}(\nu))$。一般情形下 q 可能不可微，需要先推广“梯度”。

定义 22.11 超梯度 设 q 是凹函数，$\boldsymbol{y}$ 是定义域内一点。若向量 $\boldsymbol{s}$ 使得对定义域内所有 $\boldsymbol{y}'$ 都有

$$q(\boldsymbol{y}') \leq q(\boldsymbol{y}) + \langle \boldsymbol{s}, \boldsymbol{y}' - \boldsymbol{y}\rangle, \tag{22.30}$$

就称 $\boldsymbol{s}$ 是 q 在 $\boldsymbol{y}$ 处的**超梯度**（supergradient）。

它就是 $-q$ 的次梯度取负号：凹函数的图形总在这条切线下方。

定理 22.12 残差给出超梯度 设 $\boldsymbol{\lambda}\geq\mathbf{0}$，$\bar{\boldsymbol{x}}\in\boldsymbol{X}$ 是 $\mathcal{L}(\cdot,\boldsymbol{\lambda},\boldsymbol{\nu})$ 在 $\boldsymbol{X}$ 上的全局最小点。则 $(\boldsymbol{g}(\bar{\boldsymbol{x}}),\boldsymbol{h}(\bar{\boldsymbol{x}}))$ 是 q 在 $(\boldsymbol{\lambda},\boldsymbol{\nu})$ 处的一个超梯度。这里 $\boldsymbol{g}=(g_1,\dots,g_m)$，$\boldsymbol{h}=(h_1,\dots,h_p)$，即对所有 $\boldsymbol{\lambda}'$ 和 $\boldsymbol{\nu}'$，有

$$q(\boldsymbol{\lambda}',\boldsymbol{\nu}') \leq q(\boldsymbol{\lambda},\boldsymbol{\nu}) + \langle \boldsymbol{g}(\bar{\boldsymbol{x}}),\boldsymbol{\lambda}'-\boldsymbol{\lambda}\rangle + \langle \boldsymbol{h}(\bar{\boldsymbol{x}}),\boldsymbol{\nu}'-\boldsymbol{\nu}\rangle. \tag{22.31}$$

证明 q 是下确界，所以它不超过任一点上的值：

$$q(\boldsymbol{\lambda}',\boldsymbol{\nu}') \leq \mathcal{L}(\bar{\boldsymbol{x}},\boldsymbol{\lambda}',\boldsymbol{\nu}').$$

$\mathcal{L}$ 关于乘子是线性的，把乘子的差分拆出来：

$$\mathcal{L}(\bar{\boldsymbol{x}},\boldsymbol{\lambda}',\boldsymbol{\nu}') = \mathcal{L}(\bar{\boldsymbol{x}},\boldsymbol{\lambda},\boldsymbol{\nu}) + \langle \boldsymbol{g}(\bar{\boldsymbol{x}}),\boldsymbol{\lambda}'-\boldsymbol{\lambda}\rangle + \langle \boldsymbol{h}(\bar{\boldsymbol{x}}),\boldsymbol{\nu}'-\boldsymbol{\nu}\rangle.$$

$\bar{\boldsymbol{x}}$ 是全局最小点，所以上式右端第一项等于 $q(\boldsymbol{\lambda},\boldsymbol{\nu})$。代入即得结论。 ■

证明中只有最后一步用到了最小点，而且必须是全局最小点。若 $\bar{\boldsymbol{x}}$ 只是局部最小点，$\mathcal{L}(\bar{\boldsymbol{x}}, \boldsymbol{\lambda}, \boldsymbol{\nu})$ 比 $q(\boldsymbol{\lambda}, \boldsymbol{\nu})$ 大，式 (22.31)就失去了依据，残差不再是可靠的上升信息。若子问题只解到

$$\mathcal{L}(\bar{\boldsymbol{x}}, \boldsymbol{\lambda}, \boldsymbol{\nu}) \le q(\boldsymbol{\lambda}, \boldsymbol{\nu}) + \epsilon,$$

同样的证明给出多一项 ϵ 的不等式，$\mathcal{L}(\bar{\boldsymbol{x}}, \boldsymbol{\lambda}, \boldsymbol{\nu}) - \epsilon$ 仍是可靠的下界。

主要思想　沿超梯度走一步，不等式乘子投影回非负象限。这就是**对偶上升法**（dual ascent）：

$$\begin{aligned} \boldsymbol{x}^{(t)} &\in \arg\min_{\boldsymbol{x} \in \boldsymbol{X}} \mathcal{L}(\boldsymbol{x}, \boldsymbol{\lambda}^{(t)}, \boldsymbol{\nu}^{(t)}), \\ \boldsymbol{\lambda}^{(t+1)} &= \left[\boldsymbol{\lambda}^{(t)} + \alpha^{(t)} \boldsymbol{g}(\boldsymbol{x}^{(t)})\right]_+, \\ \boldsymbol{\nu}^{(t+1)} &= \boldsymbol{\nu}^{(t)} + \alpha^{(t)} \boldsymbol{h}(\boldsymbol{x}^{(t)}). \end{aligned} \tag{22.32}$$

读法和定价一样。某条约束被违反，$g_i > 0$，它的价格就上涨；有余量时，价格下降，但不能跌破零。等式约束的价格可正可负，没有截断。

计算过程　用二元例走一遍，$\boldsymbol{X} = \mathbb{R}^2$。

变量

- $\boldsymbol{\nu}^{(t)} \in \mathbb{R}^p$：当前乘子。例中 $p = 1$。
- $\boldsymbol{x}^{(t)} \in \mathbb{R}^n$：Lagrange 子问题的解。例中 $n = 2$。
- $\alpha^{(t)} > 0$：乘子步长。

初始化　取 $\boldsymbol{\nu}^{(0)}$ 和步长。例中 $\nu^{(0)} = 0$，步长固定为 $\alpha = 0.6$，结束容差 $\varepsilon = 0.05$。

每轮更新

1. 解 Lagrange 子问题。例中用式 (22.27)，第一轮

$$\boldsymbol{x}^{(0)} = (0, 0).$$

2. 计算残差。例中第一轮

$$h(\boldsymbol{x}^{(0)}) = -4.$$

3. 按式 (22.32)更新乘子。例中第一轮

$$\nu^{(1)} = 0 + 0.6 \times (-4) = -2.4.$$

第二轮得到

$$\boldsymbol{x}^{(1)} = (2.4,\ 0.8), \qquad h(\boldsymbol{x}^{(1)}) = -0.8, \qquad \nu^{(2)} = -2.88.$$

第三轮得到

$$\boldsymbol{x}^{(2)} = (2.88,\ 0.96), \qquad h(\boldsymbol{x}^{(2)}) = -0.16, \qquad \nu^{(3)} = -2.976.$$

第四轮得到

$$\boldsymbol{x}^{(3)} = (2.976,\ 0.992), \qquad h(\boldsymbol{x}^{(3)}) = -0.032.$$

结束条件是残差不超过 ε，例中第四轮满足。最终得到的点是 $\boldsymbol{x}^{(3)} = (2.976,\ 0.992)$，四轮对应的下界依次是

$$q(\nu^{(0)}) = 0, \quad q(\nu^{(1)}) = 5.76, \quad q(\nu^{(2)}) = 5.9904, \quad q(\nu^{(3)}) \approx 5.9996,$$

单调升向 $f^\star = 6$。但是每一轮的 $\boldsymbol{x}^{(t)}$ 都不可行。对偶上升改进的是下界，不是可行性。

步长的范围 每轮更新代入后可以写成闭式。把 $h(\boldsymbol{x}(\nu)) = -\frac{4}{3}\nu - 4$ 代入，

$$\nu^{(t+1)} + 3 = \Big(1 - \frac{4}{3}\alpha\Big)(\nu^{(t)} + 3).$$

因此收敛当且仅当 $|1 - \frac{4}{3}\alpha| < 1$，也就是 $0 < \alpha < \frac{3}{2}$。

图 22.11比较两个步长。$\alpha = 0.6$ 时压缩因子是 0.2，一步比一步接近顶点。$\alpha = 1.5$ 恰好在边界上，因子是 -1：乘子在 0 和 -6 之间永远跳动，$\boldsymbol{x}$ 在 $(0,0)$ 和 $(6,2)$ 之间跳动，两个点都不可行。

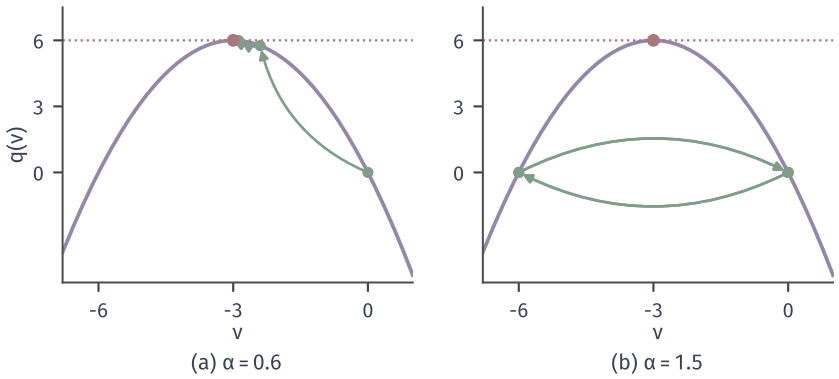


图 22.11 二元例中对偶函数 $q(\nu)$（紫）上的对偶上升。绿点和箭头是乘子序列，从 $\nu^{(0)} = 0$ 出发，红点是最大点，红色点线是 $f^\star = 6$。(a)$\alpha = 0.6$：压缩因子 0.2，很快接近最大点。(b)$\alpha = 1.5$：在 0 与 -6 之间反复跳动，不收敛。

可微的情形　例子中的 q 是光滑的，这并非偶然。当 f 强凸、约束仿射时，子问题的解唯一，超梯度也唯一，对偶函数可以用第 5章的光滑分析。

定理 22.13　强凸目标的光滑对偶　设 f 连续可微且 μ 强凸，$\boldsymbol{X}=\mathbb{R}^n$，约束为 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$。记 $\boldsymbol{x}(\boldsymbol{\nu})$ 为 $\mathcal{L}(\cdot,\boldsymbol{\nu})$ 的唯一最小点。则 q 可微，并且

$$\nabla q(\boldsymbol{\nu})=\boldsymbol{A}\boldsymbol{x}(\boldsymbol{\nu})-\boldsymbol{b}, \tag{22.33}$$

其梯度满足

$$\|\nabla q(\boldsymbol{\nu}_1)-\nabla q(\boldsymbol{\nu}_2)\|_2\le\frac{\|\boldsymbol{A}\|_2^2}{\mu}\|\boldsymbol{\nu}_1-\boldsymbol{\nu}_2\|_2. \tag{22.34}$$

于是只要最优乘子存在，固定步长 $0<\alpha<2\mu/\|\boldsymbol{A}\|_2^2$ 的对偶上升满足 $q(\boldsymbol{\nu}^{(t)})\to d^\star$，其中 $d^\star$ 是对偶最优值。

证明　记 $\boldsymbol{x}_k=\boldsymbol{x}(\boldsymbol{\nu}_k)$。驻定条件给出 $\nabla f(\boldsymbol{x}_k)=-\boldsymbol{A}^{\top}\boldsymbol{\nu}_k$。由强凸性，

$$\mu\|\boldsymbol{x}_1-\boldsymbol{x}_2\|_2^2\le\langle\nabla f(\boldsymbol{x}_1)-\nabla f(\boldsymbol{x}_2),\boldsymbol{x}_1-\boldsymbol{x}_2\rangle.$$

把驻定条件代入，并用 Cauchy–Schwarz 不等式，得到

$$\mu\|\boldsymbol{x}_1-\boldsymbol{x}_2\|_2^2\le-\langle\boldsymbol{\nu}_1-\boldsymbol{\nu}_2,\boldsymbol{A}(\boldsymbol{x}_1-\boldsymbol{x}_2)\rangle\le\|\boldsymbol{A}\|_2\|\boldsymbol{\nu}_1-\boldsymbol{\nu}_2\|_2\|\boldsymbol{x}_1-\boldsymbol{x}_2\|_2.$$

两边约去一个因子，得到

$$\|\boldsymbol{x}_1-\boldsymbol{x}_2\|_2\le\frac{\|\boldsymbol{A}\|_2}{\mu}\|\boldsymbol{\nu}_1-\boldsymbol{\nu}_2\|_2.$$

记 $\boldsymbol{s}(\boldsymbol{\nu})=\boldsymbol{A}\boldsymbol{x}(\boldsymbol{\nu})-\boldsymbol{b}$。由上式，$\boldsymbol{s}$ 满足式 (22.34)的 Lipschitz 界。

由定理 22.12，$\boldsymbol{s}(\boldsymbol{\nu}_1)$ 和 $\boldsymbol{s}(\boldsymbol{\nu}_2)$ 分别是两点的超梯度。对两点分别写一次超梯度不等式，得到

$$\langle\boldsymbol{s}(\boldsymbol{\nu}_2),\boldsymbol{\nu}_2-\boldsymbol{\nu}_1\rangle\le q(\boldsymbol{\nu}_2)-q(\boldsymbol{\nu}_1)\le\langle\boldsymbol{s}(\boldsymbol{\nu}_1),\boldsymbol{\nu}_2-\boldsymbol{\nu}_1\rangle.$$

上下两端相差不超过 $\|\boldsymbol{s}(\boldsymbol{\nu}_2)-\boldsymbol{s}(\boldsymbol{\nu}_1)\|_2\|\boldsymbol{\nu}_2-\boldsymbol{\nu}_1\|_2$，这是 $\|\boldsymbol{\nu}_2-\boldsymbol{\nu}_1\|_2$ 的二阶量，所以 q 在 $\boldsymbol{\nu}_1$ 处可微，梯度是 $\boldsymbol{s}(\boldsymbol{\nu}_1)$。

最后，$-q$ 是光滑凸函数，步长范围内的梯度法收敛结论见第 5章和第 6章。 ■

在二元例中，$\boldsymbol{A}=(1,1)$，$\|\boldsymbol{A}\|_2^2=2$，f 的强凸常数 $\mu=1$，定理的步长上限是 1，比实际范围 $\tfrac{3}{2}$ 保守。这是因为定理把两个坐标方向的曲率都按最小值 $\mu=1$ 估计，而实际的 $|q''|$ 只有 $\tfrac{4}{3}$。

22.1 二次惩罚法
22.2 精确惩罚法
22.3 对偶上升
22.3.1 残差与乘子更新
22.3.2 对偶分解与原始恢复
22.4 增广 Lagrange 法（ALM）
22.5 交替方向乘子法（ADMM）
22.6 方法比较与计算成本
22.7 本章小结

不可微的情形 f 不强凸时，子问题的解可能不唯一，q 在这些点上有折角。下面的例子有两个变量和一条资源约束，后面还要继续使用：

$$\min_{\boldsymbol{x}\in[0,1]^2} \; -x_1 - x_2 \qquad \text{s.t.} \qquad 2x_1 + 2x_2 \le 3. \tag{22.35}$$

它的最优值 $f^\star = -1.5$，在 $x_1 + x_2 = 1.5$ 的线段上取得。固定 $\lambda \ge 0$，子问题对两个变量是分开的线性函数，每个变量的系数是 $2\lambda - 1$。

因此 $\lambda < \frac{1}{2}$ 时解是 $(1,1)$，$\lambda > \frac{1}{2}$ 时解是 $(0,0)$，$\lambda = \frac{1}{2}$ 时任意点都是解。代入得到对偶函数：

$$q(\lambda) = \begin{cases} \lambda - 2, & \lambda \le \frac{1}{2}, \\ -3\lambda, & \lambda \ge \frac{1}{2}. \end{cases}$$

q 在 $\lambda^\star = \frac{1}{2}$ 处达到最大值 -1.5，折角正好在最优点上。

超梯度步未必提高 q。取 $\alpha = 0.12$，$\lambda^{(0)} = 0$，乘子序列是

$$0,\ 0.12,\ 0.24,\ 0.36,\ 0.48,\ 0.60,\ 0.24,\ 0.36,\ 0.48,\ 0.60, \ldots$$

对偶值 $q(0.48) = -1.52$，下一步 $q(0.60) = -1.8$，反而下降了。这与第 11章的次梯度法一样：步子越过折角就会下降，能保证的是到最优乘子的距离或者最好点的对偶值，而不是每步上升。图 22.13(a) 中的绿点就在折角两侧来回。

22.3.2 对偶分解与原始恢复

这一小节回答两个问题：对偶上升的计算好在哪里，以及算到最后怎样得到一个能用的原始解。

固定价格后各块分离 设变量分成 K 块，目标按块可分，只有一条线性资源约束把它们联系起来：

$$\min_{\boldsymbol{x}_k \in \boldsymbol{X}_k} \; \sum_{k=1}^{K} f_k(\boldsymbol{x}_k) \qquad \text{s.t.} \qquad \sum_{k=1}^{K} \boldsymbol{A}_k \boldsymbol{x}_k \le \boldsymbol{b}. \tag{22.36}$$

固定乘子 $\boldsymbol{\lambda} \ge \boldsymbol{0}$，Lagrange 函数按块拆开：

$$\mathcal{L}(\boldsymbol{x}, \boldsymbol{\lambda}) = \sum_{k=1}^{K} \Big(f_k(\boldsymbol{x}_k) + \langle \boldsymbol{\lambda}, \boldsymbol{A}_k \boldsymbol{x}_k \rangle \Big) - \langle \boldsymbol{\lambda}, \boldsymbol{b} \rangle.$$

和式中的每一项只含一块变量，所以 K 个子问题可以独立求解，互不通信。这种做法称为**对偶分解**（dual decomposition）。

协调者只做一件事：收集各块的用量 $\boldsymbol{A}_k\boldsymbol{x}_k$，算出总残差，按下式更新价格：

$$\boldsymbol{\lambda}^{(t+1)} = \Big[\boldsymbol{\lambda}^{(t)} + \alpha^{(t)}\Big(\sum_{k=1}^{K} \boldsymbol{A}_k\boldsymbol{x}_k^{(t)} - \boldsymbol{b}\Big)\Big]_+ . \tag{22.37}$$

图 22.12以二元例为例，它本身就是两块问题：每家工厂只知道自己的成本和价格，协调者只知道总量和目标。

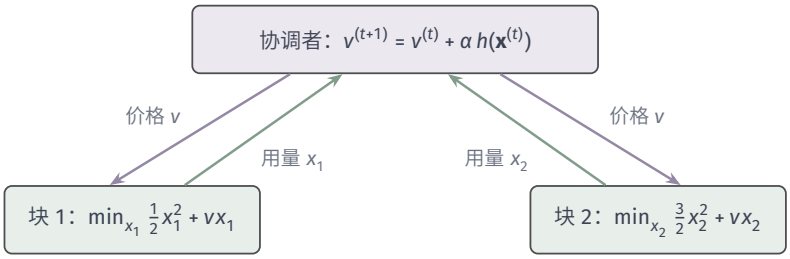


图 22.12　二元例的对偶分解。协调者（紫框）把当前价格 v 发给各块（紫色箭头），两块（绿框）独立求解自己的子问题，再把用量报回（绿色箭头）。协调者只用总量更新价格，不需要知道各块的成本函数。

分解改变的是计算的组织方式，算法在数学上仍是同一个对偶上升。收敛性质不因为分块而变好，第 12章处理的是目标本身不可分的分块，这里的分块靠乘子把约束解开。

原始点不可行　继续看式 (22.35)。两个变量的子问题总是给出 $(1,1)$ 或 $(0,0)$。前者违反资源约束，$2x_1 + 2x_2 = 4 > 3$；后者可行，目标值却是 0，离 $f^\star$ 很远。图 22.13(b) 的绿线就是这种情况：总量 $x_1 + x_2$ 一直在 2 和 0 之间跳，从不等于最优所需的 1.5。

原因在于，对偶上升求的是价格，给定价格之后，解可以停在子问题解集的任何一点上。这个例子里，$\lambda^\star = \frac{1}{2}$ 处的子问题有无穷多解，q 的最大点却完全不告诉我们选哪个。

平均恢复　第 11章在次梯度法上用过的平均，这里有直接的物理含义。把 λ 上涨的轮次看成资源用多了，下跌的轮次看成用少了，平均之后用量大致等于资源总量。图 22.13(b) 的黄线是 $x_1^{(t)} + x_2^{(t)}$ 的累积平均，它趋于 1.5。

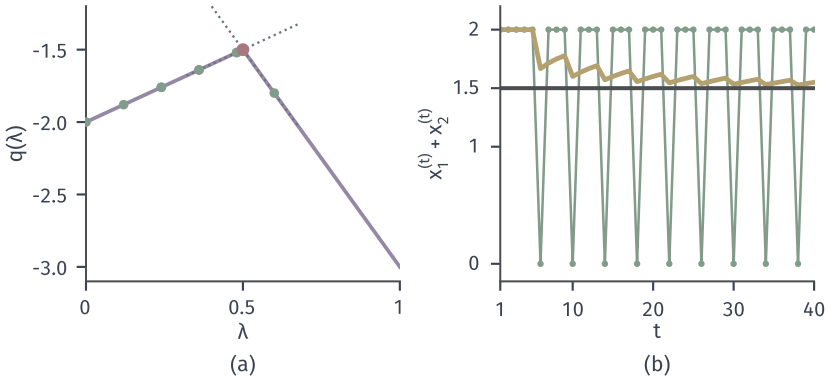


图 22.13　资源问题的超梯度上升，$\alpha = 0.12$。(a) 紫线是对偶函数，折角在 $\lambda^\star = \frac{1}{2}$，灰色点线是折角处的两条支撑线，绿点是前九个乘子，红点是最大点。(b) 绿线是每轮的总量 $x_1^{(t)} + x_2^{(t)}$，在 2 与 0 之间跳动；黄线是累积平均，深灰线是 1.5。

定理 22.14　平均点的可行性与目标　设 f 和 g_i 在非空紧凸集 $\boldsymbol{X}$ 上凸且连续，问题只有不等式约束，$f^\star$ 有限。设 $\|\boldsymbol{g}(\boldsymbol{x})\|_2 \le S$ 对 $\boldsymbol{x} \in \boldsymbol{X}$ 成立。从 $\boldsymbol{\lambda}^{(0)} \ge \boldsymbol{0}$ 出发，取固定步长 $\alpha > 0$ 运行式 (22.32)。记 $\bar{\boldsymbol{x}}^{(T)}$ 为 $\boldsymbol{x}^{(0)}, \dots, \boldsymbol{x}^{(T-1)}$ 的算术平均，则平均点在 $\boldsymbol{X}$ 内，并且

$$\boldsymbol{g}(\bar{\boldsymbol{x}}^{(T)}) \le \frac{\boldsymbol{\lambda}^{(T)}}{\alpha T}, \tag{22.38}$$

$$f(\bar{\boldsymbol{x}}^{(T)}) - f^\star \le \frac{\|\boldsymbol{\lambda}^{(0)}\|_2^2}{2\alpha T} + \frac{\alpha S^2}{2}. \tag{22.39}$$

证明　先证可行性。投影只会让乘子变大，$[a]_+ \ge a$，所以

$$\boldsymbol{\lambda}^{(t+1)} \ge \boldsymbol{\lambda}^{(t)} + \alpha \boldsymbol{g}(\boldsymbol{x}^{(t)}).$$

对 $t = 0, \dots, T-1$ 求和，得到

$$\alpha \sum_{t=0}^{T-1} \boldsymbol{g}(\boldsymbol{x}^{(t)}) \le \boldsymbol{\lambda}^{(T)} - \boldsymbol{\lambda}^{(0)} \le \boldsymbol{\lambda}^{(T)}.$$

每个 g_i 是凸函数，由 Jensen 不等式，平均点上的函数值不超过函数值的平均：

$$g_i(\bar{\boldsymbol{x}}^{(T)}) \le \frac{1}{T} \sum_{t=0}^{T-1} g_i(\boldsymbol{x}^{(t)}).$$

两式结合，除以 αT，即得式 (22.38)。

再证目标。投影到非负象限不增加与原点的距离，所以

$$\|\boldsymbol{\lambda}^{(t+1)}\|_2^2 \le \|\boldsymbol{\lambda}^{(t)} + \alpha \boldsymbol{g}(\boldsymbol{x}^{(t)})\|_2^2 \le \|\boldsymbol{\lambda}^{(t)}\|_2^2 + 2\alpha \langle \boldsymbol{\lambda}^{(t)}, \boldsymbol{g}(\boldsymbol{x}^{(t)}) \rangle + \alpha^2 S^2.$$

由弱对偶和 $\boldsymbol{x}^{(t)}$ 的定义，

$$f(\boldsymbol{x}^{(t)}) + \langle \boldsymbol{\lambda}^{(t)}, \boldsymbol{g}(\boldsymbol{x}^{(t)}) \rangle = q(\boldsymbol{\lambda}^{(t)}) \le f^\star.$$

从上式解出内积，代入前一个不等式，得到

$$f(\boldsymbol{x}^{(t)}) - f^\star \le \frac{\|\boldsymbol{\lambda}^{(t)}\|_2^2 - \|\boldsymbol{\lambda}^{(t+1)}\|_2^2}{2\alpha} + \frac{\alpha S^2}{2}.$$

对 t 求和，左边用 Jensen 不等式，右边裂项相消，去掉非正的 $-\|\boldsymbol{\lambda}^{(T)}\|_2^2$，除以 T 即得式 (22.39)。 ■

平均点的违规量由 $\boldsymbol{\lambda}^{(T)}/(\alpha T)$ 控制，只要乘子序列有界，它就以 $1/T$ 趋于零。Slater 条件可以保证有界。设 $\tilde{\boldsymbol{x}} \in \boldsymbol{X}$ 满足 $g_i(\tilde{\boldsymbol{x}}) \le -\sigma < 0$，并记 $f_{\min}$ 为 f 在 $\boldsymbol{X}$ 上的最小值。对偶函数不超过 $\mathcal{L}$ 在 $\tilde{\boldsymbol{x}}$ 处的值，由此得到

$$\langle \boldsymbol{\lambda}^{(t)}, \boldsymbol{g}(\boldsymbol{x}^{(t)}) \rangle = q(\boldsymbol{\lambda}^{(t)}) - f(\boldsymbol{x}^{(t)}) \le f(\tilde{\boldsymbol{x}}) - f_{\min} - \sigma \|\boldsymbol{\lambda}^{(t)}\|_1.$$

记

$$R = \frac{f(\tilde{\boldsymbol{x}}) - f_{\min} + \alpha S^2/2}{\sigma}.$$

代入证明中的距离递推可知，只要 $\|\boldsymbol{\lambda}^{(t)}\|_1 \ge R$，范数就不会增大；否则一步至多增加 αS。所以

$$\|\boldsymbol{\lambda}^{(t)}\|_2 \le \max\{\|\boldsymbol{\lambda}^{(0)}\|_2,\ R + \alpha S\}.$$

式 (22.39)只是单侧的界：$\bar{\boldsymbol{x}}^{(T)}$ 略微不可行时，目标值可能低于 $f^\star$。

在问题 (22.35)中，乘子进入周期后每四轮有三轮是 $(1,1)$，一轮是 $(0,0)$，平均趋于 $(\tfrac{3}{4}, \tfrac{3}{4})$，$2x_1 + 2x_2$ 趋于 3，恰好用尽资源。这组权重 $\tfrac{3}{4}, \tfrac{1}{4}$ 是从对偶迭代的频率里读出来的，并没有事先知道。

非凸时的恢复与证书　平均依赖可行集和目标的凸性。把式 (22.35)的变量改成 $x_i \in \{0,1\}$，子问题和对偶函数都不变，最优乘子仍是 $\tfrac{1}{2}$，下界最多是 -1.5。可平均点 $(\tfrac{3}{4}, \tfrac{3}{4})$ 不是整数点，平均在这里没有意义。

这时可以从访问过的点里挑选，或者另加一个简单的修复步骤，例如按边际价值贪心地放入物品，直到资源用尽。这里贪心得到 $(1,0)$，目标值 -1，可行。

22.1 二次惩罚法
22.2 精确惩罚法
22.3 对偶上升
22.4 增广 Lagrange 法（ALM）
22.4.1 原始变量与乘子更新
22.4.2 参数与停止条件
22.5 交替方向乘子法（ADMM）
22.6 方法比较与计算成本
22.7 本章小结

此时的结论要如实报告：可行解给出上界 -1，迭代中最好的对偶值给出下界 -1.52，间隙不超过 0.52。这个问题真实的最优值是 -1，对偶下界不紧是非凸问题的常态，第 18章称之为对偶间隙。任何情况下都应当同时报告原始可行性和这个间隙，单独一个收敛的对偶值不构成原问题的解。

22.4 增广 Lagrange 法（ALM）

前面两条路各有缺陷。二次罚能增加法向曲率，把子问题变成好解的碗，但违规量要靠 $\rho \to \infty$ 才能消失。对偶上升不增加任何曲率，步长稍大就振荡，目标线性时子问题甚至定不出解。把价格和罚款放在同一个函数里，能否在有限的 ρ 下得到解？

从力的平衡出发 二次罚的驻点满足 $\nabla f + \rho J^{\top} h = 0$。要平衡目标的力，$\rho h$ 必须接近 $\nu^{\star}$，所以 h 不能为零。如果事先在罚项里加上一个估计的力 ν，那么只要 ν 足够接近 $\nu^{\star}$，弹簧几乎不用拉长。

工厂的语言是，总部既标出单价，又对偏离总量收罚款。单价负责提供大部分的调节力，罚款只负责修正单价还没估准的那一小部分。写成函数，就是在 Lagrange 函数上加残差平方。

定义 22.15 增广 Lagrange 函数 对等式约束问题和 $\rho > 0$，增广 Lagrange 函数（augmented Lagrangian）是

$$\mathcal{L}_{\rho}(x, \nu) = f(x) + \langle \nu, h(x) \rangle + \frac{\rho}{2} \|h(x)\|_2^2. \tag{22.40}$$

配方之后可以看出它的结构：

$$\mathcal{L}_{\rho}(x, \nu) = f(x) + \frac{\rho}{2} \left\| h(x) + \frac{\nu}{\rho} \right\|_2^2 - \frac{1}{2\rho} \|\nu\|_2^2. \tag{22.41}$$

最后一项与 x 无关。所以固定 ν 时，增广 Lagrange 函数就是一个目标移位的二次罚：它不再要求 $h = 0$，而是把残差往 $-\nu/\rho$ 处拉。移位量选得对，平衡点上的残差就恰好是零。

同一个例子 对二元例，固定 ν 和 ρ，增广 Lagrange 函数的驻定方程是

$$(1+\rho)x_1 + \rho x_2 = 4\rho - \nu, \qquad \rho x_1 + (3+\rho)x_2 = 4\rho - \nu.$$

两式相减仍得 $x_1 = 3x_2$。代回得到

$$x_2 = \frac{4\rho - \nu}{3 + 4\rho}, \qquad x_1 = 3x_2. \tag{22.42}$$

残差因此是

$$h(\boldsymbol{x}) = 4x_2 - 4 = -\frac{4(\nu+3)}{3+4\rho}. \tag{22.43}$$

和二次罚的式 (22.7)比较，二次罚对应 $\nu = 0$，残差只能靠分母变大。这里分子含有因子 $\nu - \nu^\star = \nu + 3$：只要 $\nu = -3$，无论 ρ 多小，残差都是零。

图 22.14固定 $\rho = 1.5$，只改变 ν。等高线的形状完全不变，因为 Hessian 不依赖 ν；变的是碗底的位置，$\nu = 0$ 时离直线较远，$\nu = -2$ 时贴近直线，$\nu = -3$ 时恰好落在解上。对比图 22.2，那里要靠压扁碗才能靠近直线，这里碗的形状没有变。

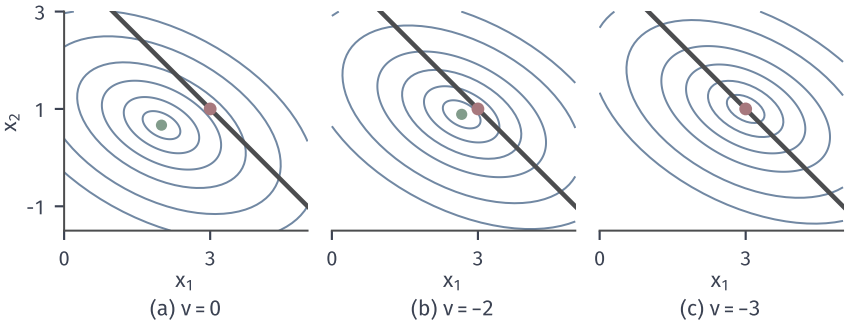


图 22.14 二元例中 $\mathcal{L}_{1.5}(\cdot,\nu)$ 的等高线（蓝），$\rho = 1.5$ 固定。深灰直线是约束，绿点是增广函数的最小点，红点是解 $(3,1)$。改变乘子只平移碗底，不改变碗的形状；(c)$\nu = \nu^\star$ 时最小点落在解上。

这种现象不只在二次例子里出现，它在局部有一般的解释。下面的定理说，只要乘子是对的，有限的 ρ 就够了。

定理 22.16 最优乘子下的局部精确性 设 f, h_j 二阶连续可微，$(\boldsymbol{x}^\star, \boldsymbol{\nu}^\star)$ 满足 KKT 条件。记 $\boldsymbol{W}$ 为 $\mathcal{L}(\cdot, \boldsymbol{\nu}^\star)$ 在 $\boldsymbol{x}^\star$ 处的 Hessian，$\boldsymbol{J} = \boldsymbol{J}(\boldsymbol{x}^\star)$，并设对所有非零 $\boldsymbol{d}$，只要 $\boldsymbol{J}\boldsymbol{d} = \boldsymbol{0}$，就有 $\boldsymbol{d}^{\top}\boldsymbol{W}\boldsymbol{d} > 0$。则存在 $\bar{\rho} \geq 0$，使 $\rho > \bar{\rho}$ 时，$\boldsymbol{x}^\star$ 是 $\mathcal{L}_\rho(\cdot, \boldsymbol{\nu}^\star)$ 的严格局部最小点。

证明 由 $\boldsymbol{h}(\boldsymbol{x}^\star) = \boldsymbol{0}$ 和 KKT 条件，

$$\nabla_{\boldsymbol{x}} \mathcal{L}_\rho(\boldsymbol{x}^\star, \boldsymbol{\nu}^\star) = \nabla f + \boldsymbol{J}^{\top}\boldsymbol{\nu}^\star + \rho \boldsymbol{J}^{\top}\boldsymbol{h} = \boldsymbol{0}.$$

含 $h_j \nabla^2 h_j$ 的项在 $\boldsymbol{x}^\star$ 处为零，所以 Hessian 是

$$\nabla^2_{\boldsymbol{x}\boldsymbol{x}} \mathcal{L}_\rho(\boldsymbol{x}^\star, \boldsymbol{\nu}^\star) = \boldsymbol{W} + \rho \boldsymbol{J}^{\top}\boldsymbol{J}.$$

只需证明 ρ 足够大时它正定。$\boldsymbol{J}^{\top}\boldsymbol{J}$ 半正定，这个矩阵关于 ρ 是单调的，一旦正定，更大的 ρ 也正定。

22.1 二次惩罚法
22.2 精确惩罚法
22.3 对偶上升
22.4 增广 Lagrange 法（ALM）
22.4.1 原始变量与乘子更新
22.4.2 参数与停止条件
22.5 交替方向乘子法（ADMM）
22.6 方法比较与计算成本
22.7 本章小结

用反证法。若对每个正整数 k，$\boldsymbol{W}+k\boldsymbol{J}^{\top}\boldsymbol{J}$ 都不正定，则存在单位向量 $\boldsymbol{u}_k$，使

$$\boldsymbol{u}_k^{\top}\boldsymbol{W}\boldsymbol{u}_k + k\|\boldsymbol{J}\boldsymbol{u}_k\|_2^2 \le 0.$$

单位向量的序列有收敛子列，设极限为 $\boldsymbol{u}$。由上式得

$$\|\boldsymbol{J}\boldsymbol{u}_k\|_2^2 \le \frac{\|\boldsymbol{W}\|_2}{k} \to 0,$$

故 $\boldsymbol{J}\boldsymbol{u}=\boldsymbol{0}$。

不等式的第二项非负，去掉它得 $\boldsymbol{u}_k^{\top}\boldsymbol{W}\boldsymbol{u}_k \le 0$，取极限得 $\boldsymbol{u}^{\top}\boldsymbol{W}\boldsymbol{u}\le 0$。这与假设矛盾，因为 $\boldsymbol{u}\neq\boldsymbol{0}$ 且 $\boldsymbol{J}\boldsymbol{u}=\boldsymbol{0}$。 ■

条件中 $\bar{\rho}$ 的作用，看一个非凸的例子。取 $f(\boldsymbol{x})=\frac{1}{2}(x_1^2-x_2^2)$，$h(\boldsymbol{x})=x_2$，解是原点，$\nu^{\star}=0$。切方向是 x_1 轴，曲率 $1>0$，满足二阶条件。此时增广函数的 Hessian 是 $\operatorname{diag}(1,\rho-1)$，必须 $\rho>1$ 才正定。$\rho<1$ 时，增广函数沿 x_2 方向没有下界。若 f 是凸函数且约束是线性的，就不需要这个门槛，任何 $\rho>0$ 都行。

22.4.1 原始变量与乘子更新

问题转到怎样得到正确的乘子。上一节的定理给了线索：用 $\boldsymbol{\nu}$ 算出的增广函数的驻点，本身就告诉我们乘子该往哪里改。

主要思想 对 $\mathcal{L}_{\rho}$ 求梯度，把含 $\boldsymbol{h}$ 的项合并，得到一个恒等式：

$$\nabla_{\boldsymbol{x}}\mathcal{L}_{\rho}(\boldsymbol{x},\boldsymbol{\nu}) = \nabla f(\boldsymbol{x}) + \boldsymbol{J}(\boldsymbol{x})^{\top}\big(\boldsymbol{\nu}+\rho\boldsymbol{h}(\boldsymbol{x})\big) = \nabla_{\boldsymbol{x}}\mathcal{L}\big(\boldsymbol{x},\boldsymbol{\nu}+\rho\boldsymbol{h}(\boldsymbol{x})\big). \tag{22.44}$$

如果 $\boldsymbol{x}^{(t+1)}$ 是增广函数的驻点，那么它对应的 Lagrange 函数在乘子 $\boldsymbol{\nu}^{(t)}+\rho\boldsymbol{h}(\boldsymbol{x}^{(t+1)})$ 处驻定。这个乘子把目标的力和约束的力平衡起来了，正好作为新的估计。

由此得到**增广 Lagrange 法**（augmented Lagrangian method，ALM）：

$$\begin{aligned}\boldsymbol{x}^{(t+1)} &\approx \arg\min_{\boldsymbol{x}} \mathcal{L}_{\rho}(\boldsymbol{x},\boldsymbol{\nu}^{(t)}),\\ \boldsymbol{\nu}^{(t+1)} &= \boldsymbol{\nu}^{(t)} + \rho\,\boldsymbol{h}(\boldsymbol{x}^{(t+1)}).\end{aligned} \tag{22.45}$$

这里 ρ 既是罚参数，也是乘子的步长。把步长取成 ρ，正是恒等式 (22.44)选出来的，不是任意的约定。

形式上它和对偶上升 (22.32)只差一点：残差的取法。对偶上升先在旧乘子下解 Lagrange 子问题，用得到的残差算新乘子。ALM 的 $\boldsymbol{x}^{(t+1)}$ 满足

的是新乘子下的驻定条件，残差实际上是在“走到之后的乘子”处读的。这正是第 11章显式步和隐式步的区别。

定理 22.17　ALM 是对偶问题的邻近点法　设 f 是适当、闭的凸函数，$\boldsymbol{h}(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}$。设 $\boldsymbol{x}^+$ 是 $\mathcal{L}_\rho(\cdot, \boldsymbol{\nu})$ 的全局最小点，$\boldsymbol{\nu}^+ = \boldsymbol{\nu} + \rho \boldsymbol{h}(\boldsymbol{x}^+)$。则 $\boldsymbol{x}^+$ 是 $\mathcal{L}(\cdot, \boldsymbol{\nu}^+)$ 的全局最小点，并且

$$\boldsymbol{\nu}^+ = \boldsymbol{\nu} + \rho \boldsymbol{s}^+, \qquad \boldsymbol{s}^+ = \boldsymbol{h}(\boldsymbol{x}^+) \text{是} q \text{在} \boldsymbol{\nu}^+ \text{处的超梯度}, \tag{22.46}$$

等价地，$\boldsymbol{\nu}^+$ 是下面问题的唯一解：

$$\boldsymbol{\nu}^+ = \arg\max_{\boldsymbol{y}} \left\{ q(\boldsymbol{y}) - \frac{1}{2\rho} \|\boldsymbol{y} - \boldsymbol{\nu}\|_2^2 \right\}. \tag{22.47}$$

证明　$\boldsymbol{x}^+$ 最小化凸函数 $\mathcal{L}_\rho(\cdot, \boldsymbol{\nu})$，最优性条件是

$$\boldsymbol{0} \in \partial f(\boldsymbol{x}^+) + \boldsymbol{A}^\top \big(\boldsymbol{\nu} + \rho(\boldsymbol{A}\boldsymbol{x}^+ - \boldsymbol{b}) \big) = \partial f(\boldsymbol{x}^+) + \boldsymbol{A}^\top \boldsymbol{\nu}^+.$$

这正是凸函数 $\mathcal{L}(\cdot, \boldsymbol{\nu}^+)$ 在 $\boldsymbol{x}^+$ 处的最优性条件，第一个结论成立。

由定理 22.12，$\boldsymbol{s}^+ = \boldsymbol{h}(\boldsymbol{x}^+)$ 是 q 在 $\boldsymbol{\nu}^+$ 处的超梯度，再由 $\boldsymbol{\nu}^+$ 的定义得式 (22.46)。

式 (22.47)中的目标强凹。它在 $\boldsymbol{\nu}^+$ 处的最优性条件是 $\boldsymbol{0}$ 属于 $\partial q(\boldsymbol{\nu}^+) - (\boldsymbol{\nu}^+ - \boldsymbol{\nu})/\rho$，而式 (22.46)正好给出这样一个超梯度。 ■

图 22.15在二元例上比较两种步。$\rho = 1.5$，从 $\nu^{(0)} = 0$ 出发，q 的斜率是 -4。显式步用当前点的斜率，走到 $0 + 1.5 \times (-4) = -6$，越过最大点，这就是图 22.11(b) 的振荡。隐式步要求落点的斜率 s 满足 $\nu^+ = \nu + 1.5s$，代入 $s = -\frac{4}{3}\nu^+ - 4$，解出 $\nu^+ = -2$，落在最大点的同一侧。

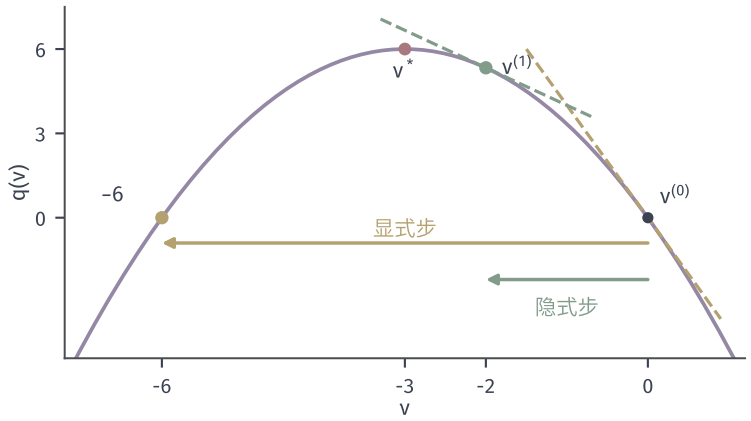


图 22.15　同样的步长 $\rho = 1.5$ 下，对偶函数（紫）上的显式步与隐式步。黄色虚线是 $\nu^{(0)} = 0$ 处的切线，显式步按它的斜率走到 -6（黄点）。绿色虚线是 $\nu^{(1)} = -2$ 处的切线，隐式步要求落点切线的斜率与步长一致，得到绿点。红点是最大点 $\nu^\star$。

	对偶上升	ALM
原始子问题	$\min \mathcal{L}(\cdot, \boldsymbol{\nu})$	$\min \mathcal{L}_\rho(\cdot, \boldsymbol{\nu})$
残差读取点	旧乘子（显式）	新乘子（隐式）
步长限制	受 q 的曲率限制	任意 $\rho > 0$（凸问题）
子问题	目标可分则可分	平方项通常耦合各块
目标线性时	子问题可能无解或解不唯一	平方项提供曲率

表 22.3　对偶上升与 ALM 的对照。ALM 用更难的子问题换取稳定的乘子更新。

压缩的速度可以显式写出。下面的定理针对最简单的等式约束二次规划，它的结论和图上的行为完全一致。

定理 22.18　线性等式二次问题的压缩率　设 f 是二次函数 $\tfrac{1}{2}\boldsymbol{x}^\top \boldsymbol{G}\boldsymbol{x} - \boldsymbol{d}^\top \boldsymbol{x}$，$\boldsymbol{G} \succ \boldsymbol{0}$，$\boldsymbol{h}(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}$，$\boldsymbol{A}$ 行满秩，记 $\boldsymbol{S} = \boldsymbol{A}\boldsymbol{G}^{-1}\boldsymbol{A}^\top$。则精确求解子问题的 ALM 满足

$$\boldsymbol{\nu}^{(t+1)} - \boldsymbol{\nu}^\star = (\boldsymbol{I} + \rho \boldsymbol{S})^{-1}(\boldsymbol{\nu}^{(t)} - \boldsymbol{\nu}^\star), \tag{22.48}$$

于是

$$\|\boldsymbol{\nu}^{(t+1)} - \boldsymbol{\nu}^\star\|_2 \le \frac{1}{1 + \rho\, \lambda_{\min}(\boldsymbol{S})} \|\boldsymbol{\nu}^{(t)} - \boldsymbol{\nu}^\star\|_2. \tag{22.49}$$

证明　由恒等式 (22.44)，$\boldsymbol{x}^{(t+1)}$ 满足

$$\boldsymbol{G}\boldsymbol{x}^{(t+1)} - \boldsymbol{d} + \boldsymbol{A}^{\top}\boldsymbol{\nu}^{(t+1)} = \boldsymbol{0},$$

解出

$$\boldsymbol{x}^{(t+1)} = \boldsymbol{G}^{-1}(\boldsymbol{d} - \boldsymbol{A}^{\top}\boldsymbol{\nu}^{(t+1)}).$$

代入乘子更新式，得到

$$\boldsymbol{\nu}^{(t+1)} - \boldsymbol{\nu}^{(t)} = \rho\big(\boldsymbol{A}\boldsymbol{G}^{-1}\boldsymbol{d} - \boldsymbol{S}\boldsymbol{\nu}^{(t+1)} - \boldsymbol{b}\big).$$

$\boldsymbol{\nu}^{\star}$ 满足同样形式的方程

$$\boldsymbol{A}\boldsymbol{G}^{-1}\boldsymbol{d} - \boldsymbol{S}\boldsymbol{\nu}^{\star} - \boldsymbol{b} = \boldsymbol{0},$$

两式相减，得到

$$\boldsymbol{\nu}^{(t+1)} - \boldsymbol{\nu}^{(t)} = -\rho\boldsymbol{S}(\boldsymbol{\nu}^{(t+1)} - \boldsymbol{\nu}^{\star}).$$

移项得

$$(\boldsymbol{I} + \rho\boldsymbol{S})(\boldsymbol{\nu}^{(t+1)} - \boldsymbol{\nu}^{\star}) = \boldsymbol{\nu}^{(t)} - \boldsymbol{\nu}^{\star},$$

即式 (22.48)。$\boldsymbol{S}$ 对称正定，取范数即得式 (22.49)。 ■

二元例中 $\boldsymbol{S} = 1 + \tfrac{1}{3} = \tfrac{4}{3}$，压缩因子是 $3/(3+4\rho)$，$\rho = 1.5$ 时为 $\tfrac{1}{3}$。任何 $\rho > 0$ 都是压缩的，和对偶上升要求 $\alpha < \tfrac{3}{2}$ 形成对比。

计算过程　仍用二元例，并沿用第 22.1.1小节的外层容差。

变量

- $\boldsymbol{\nu}^{(t)} \in \mathbb{R}^{p}$：乘子估计。例中 $p = 1$。
- $\boldsymbol{x}^{(t)} \in \mathbb{R}^{n}$：增广子问题的解。例中 $n = 2$。
- $\rho > 0$：罚参数，下一小节讨论它的调整。

初始化　取 $\boldsymbol{\nu}^{(0)}$ 和 ρ。例中 $\nu^{(0)} = 0$，$\rho = 1.5$，外层容差 $\varepsilon = 0.05$。

每轮更新

1. 近似最小化 $\mathcal{L}_{\rho}(\cdot, \boldsymbol{\nu}^{(t)})$。例中由式 (22.42)，$\rho = 1.5$ 时 $x_2 = (6 - \nu)/9$，第一轮

$$\boldsymbol{x}^{(1)} = \Big(2,\ \frac{2}{3}\Big).$$

2. 计算残差。例中第一轮

$$h(\boldsymbol{x}^{(1)}) = -\frac{4}{3}.$$

3. 由式 (22.45)更新乘子。例中第一轮

$$\nu^{(1)} = 0 + 1.5 \times \left(-\frac{4}{3}\right) = -2.$$

第二轮得到

$$\boldsymbol{x}^{(2)} = \left(\frac{8}{3}, \frac{8}{9}\right), \qquad h(\boldsymbol{x}^{(2)}) = -\frac{4}{9}, \qquad \nu^{(2)} = -\frac{8}{3}.$$

第三轮得到

$$\boldsymbol{x}^{(3)} = \left(\frac{26}{9}, \frac{26}{27}\right), \qquad h(\boldsymbol{x}^{(3)}) = -\frac{4}{27}, \qquad \nu^{(3)} = -\frac{26}{9}.$$

第四轮得到

$$\boldsymbol{x}^{(4)} = \left(\frac{80}{27}, \frac{80}{81}\right), \qquad h(\boldsymbol{x}^{(4)}) = -\frac{4}{81} \approx -0.049.$$

结束条件是 $|h| \le \varepsilon$，例中第四轮满足。最终得到 $\boldsymbol{x}^{(4)} \approx (2.963, 0.988)$，更新后的乘子是 $\nu^{(4)} = -\frac{80}{27} \approx -2.963$。

第一轮和二次罚 $\rho = 1.5$ 的结果相同，因为此时 $\nu = 0$。此后二次罚换 ρ，ALM 换 ν。用相同的梯度法作内层，四轮分别用 21、18、15、12 步，共 66 步，ρ 一直是 1.5，条件数一直是 3.1。

图 22.16(a) 比较两种方法。按外层轮数看，二次罚（ρ 每轮乘 10）下降得更快；但它每一轮都在解一个更病态的问题。ALM 每轮只把残差缩小到 $\frac{1}{3}$，却始终在解同一个条件数很小的问题。(b) 是 ALM 中 ρ 的取舍：ρ 越大，外层压缩因子越小，轮数越少，内层条件数越大。

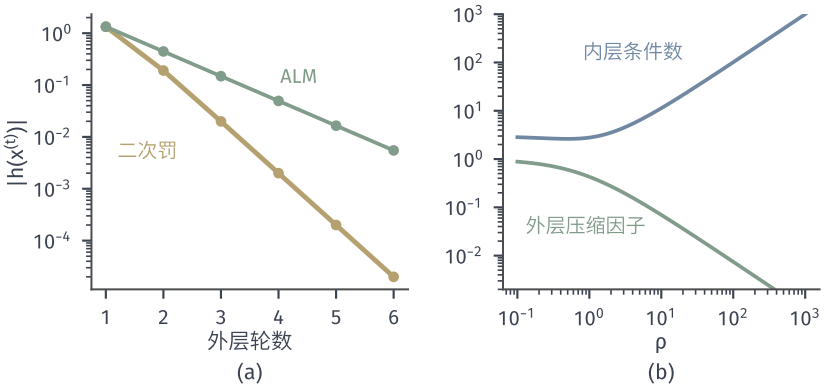


图 22.16 二元例上 ALM 与二次罚的对比。(a) 半对数坐标下的约束残差：黄线是二次罚（ρ 从 1.5 开始每轮乘 10），绿线是 ALM（$\rho = 1.5$ 固定），每轮精确求解。(b) 双对数坐标，绿线是 ALM 的外层压缩因子 $3/(3+4\rho)$，蓝线是内层 Hessian 的条件数。

不等式约束 前面的公式都是等式约束，不等式约束的乘子有符号限制，不能直接照搬。标准的做法是加入非负松弛变量，把 $g_i(\boldsymbol{x}) \le 0$ 写成 $g_i(\boldsymbol{x}) + s_i = 0$，$s_i \ge 0$，然后只对这个等式写增广函数。

固定 $\boldsymbol{x}$，把 s_i 的优化解出来。对第 i 条约束，要在 $s_i \ge 0$ 上最小化

$$\lambda_i(g_i + s_i) + \frac{\rho}{2}(g_i + s_i)^2.$$

这是 s_i 的凸二次函数，无约束极小点是 $-g_i - \lambda_i/\rho$，投影到非负数后得到

$$s_i = \Big[-g_i - \frac{\lambda_i}{\rho}\Big]_+.$$

由此可得 $g_i + s_i = \max\{g_i, -\lambda_i/\rho\}$。把它代回去，分 $g_i \ge -\lambda_i/\rho$ 和 $g_i < -\lambda_i/\rho$ 两种情形合并，增广函数为

$$\mathcal{L}_\rho(\boldsymbol{x}, \boldsymbol{\lambda}) = f(\boldsymbol{x}) + \frac{1}{2\rho}\sum_{i=1}^{m}\Big([\lambda_i + \rho g_i(\boldsymbol{x})]_+^2 - \lambda_i^2\Big). \tag{22.50}$$

乘子沿松弛等式更新，$\lambda_i^+ = \lambda_i + \rho(g_i + s_i)$，整理后是

$$\lambda_i^+ = \big[\lambda_i + \rho g_i(\boldsymbol{x})\big]_+. \tag{22.51}$$

这个公式自动带来了对偶可行和互补。λ_i^+ 是正部，所以非负。若 $g_i < -\lambda_i/\rho$，约束有足够余量，$\lambda_i^+ = 0$，该约束暂时不起作用。不动点 $\lambda_i^+ = \lambda_i$ 等价于 $\max\{g_i, -\lambda_i/\rho\} = 0$，它恰好是

$$g_i \le 0, \qquad \lambda_i \ge 0, \qquad \lambda_i g_i = 0. \tag{22.52}$$

22.1 二次惩罚法
22.2 精确惩罚法
22.3 对偶上升
22.4 增广 Lagrange 法（ALM）
22.4.1 原始变量与乘子更新
22.4.2 参数与停止条件
22.5 交替方向乘子法（ADMM）
22.6 方法比较与计算成本
22.7 本章小结

图 22.17(a) 是单条约束的代价：在 $g \ge -\lambda/\rho$ 一侧是二次增长的曲线，另一侧是常数 $-\lambda^2/(2\rho)$，两段光滑相接。(b) 是乘子更新，折线在 $-\lambda/\rho$ 处把负值截断。

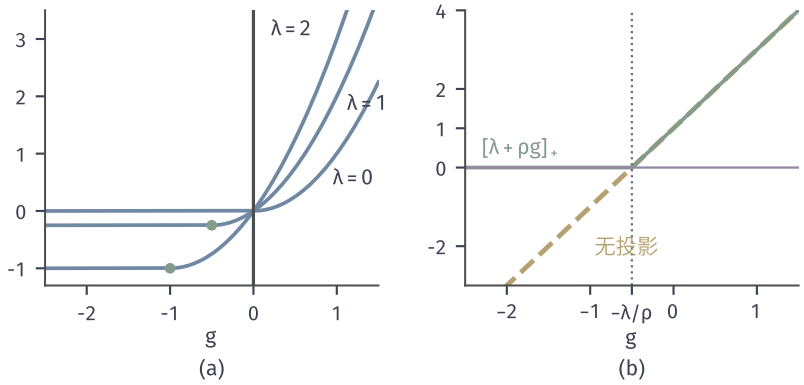


图 22.17　不等式约束的增广项，$\rho = 2$。(a) 蓝线是 $([\lambda + \rho g]_+^2 - \lambda^2)/(2\rho)$ 关于 g 的曲线，$\lambda = 0, 1, 2$，绿点是分段点 $g = -\lambda/\rho$，深灰竖线是约束边界。(b)$\lambda = 1$ 的乘子更新：绿线是投影形式 $[\lambda + \rho g]_+$，黄色虚线是不作投影的直线，紫线是零。

用一维例检验。式 (22.2)的 $g = 1 - x$，式 (22.50)对 x 的导数是

$$1 - [\lambda + \rho(1 - x)]_+.$$

令其为零，得到

$$x = 1 + \frac{\lambda - 1}{\rho}.$$

此时 $\lambda + \rho(1 - x) = 1$，所以由式 (22.51)，不管 λ 从哪里开始，一次更新后都有 $\lambda^+ = 1 = \lambda^\star$。第二轮代入，$x = 1$，就是原问题的解。二次罚在同一例上永远差 $1/\rho$。

不作投影会出错。考虑 $\min x^2$, $x \ge -1$, 解 $x^\star = 0$, 约束不活动, $\lambda^\star = 0$。写 $g = -1 - x$，取 $\rho = 2$，$\lambda^{(0)} = 0$。式 (22.51)给出 $\lambda^+ = 0$，一步就对。

若把它当作等式，用不带投影的公式，子问题的解是 $x = (\lambda - 2)/4$，乘子递推是 $\lambda^+ = \frac{1}{2}\lambda - 1$。序列 $\lambda = 0, -1, -1.5, \ldots$ 趋于 -2，x 趋于 -1。这是把约束当作 $x = -1$ 时的解，既不是原问题的解，乘子的符号也错了。

22.4.2 参数与停止条件

ALM 的结构已经确定，剩下三件事：什么时候放大 ρ，子问题解到多准，什么时候算结束。

罚参数　不必让 ρ 趋于无穷，但也不能太小。ρ 太小时，一方面非凸问题的子问题可能无下界，另一方面外层压缩很慢。常用的规则是观察约束残差是否下降到位。把等式残差和不等式残差放在同一个向量里：

$$\boldsymbol{c}^{(t)} = \Big(\boldsymbol{h}(\boldsymbol{x}^{(t)}),\ \max\{\boldsymbol{g}(\boldsymbol{x}^{(t)}), -\boldsymbol{\lambda}^{(t-1)}/\rho^{(t-1)}\} \Big), \tag{22.53}$$

其中 max 按分量取。它把不活动约束的残差也按互补要求记为零。若

$$\|\boldsymbol{c}^{(t+1)}\|_2 > \theta \|\boldsymbol{c}^{(t)}\|_2, \tag{22.54}$$

说明残差下降不够，令 $\rho \leftarrow \beta\rho$，否则保持 ρ 不变。常见取值是 $\theta \in [0.25, 0.5]$，$\beta \in [2, 10]$。

顺序上，先用当前的 ρ 更新乘子，再放大 ρ。乘子本身是一个不依赖 ρ 的量，放大 ρ 不需要换算它。

例如二元例若从 $\rho = 0.15$ 开始，压缩因子是 $3/3.6 \approx 0.83$。第一轮和第二轮的结果为

$$h(\boldsymbol{x}^{(1)}) = -\frac{10}{3}, \qquad h(\boldsymbol{x}^{(2)}) = -\frac{25}{9}.$$

第二轮的残差比是 0.83，大于 $\theta = 0.5$，所以把 ρ 放大到 1.5，此后压缩因子变成 $\frac{1}{3}$。

内层精度　恒等式 (22.44)给出了一个便利之处：增广函数的内层梯度 $\|\nabla_{\boldsymbol{x}} \mathcal{L}_\rho(\boldsymbol{x}, \boldsymbol{\nu}^{(t)})\|_2$，正是更新后的乘子下 Lagrange 驻定残差。所以内层容差就是外层驻定精度，不用另算。

外层初期乘子还不准，把子问题解得太细是浪费。常用的安排是让内层容差 $\omega^{(t)}$ 随外层逐步收紧，最终降到所需的驻定精度。对凸问题，邻近点法的分析要求内层误差可和，$\sum_t \epsilon^{(t)} < \infty$；实现上也常用与约束残差挂钩的相对准则。

三类残差　结束时要分别检查三项，任何一项不合格都不算解好：

$$\begin{aligned} \text{原始可行：}&\quad \|\boldsymbol{h}(\boldsymbol{x})\|_2,\ \|[\boldsymbol{g}(\boldsymbol{x})]_+\|_2 \le \varepsilon_{\mathrm{p}}, \\ \text{Lagrange 驻定：}&\quad \|\nabla_{\boldsymbol{x}} \mathcal{L}(\boldsymbol{x}, \boldsymbol{\lambda}^+, \boldsymbol{\nu}^+)\|_2 \le \varepsilon_{\mathrm{d}}, \\ \text{互补：}&\quad \|\min\{-\boldsymbol{g}(\boldsymbol{x}), \boldsymbol{\lambda}^+\}\|_2 \le \varepsilon_{\mathrm{c}}. \end{aligned} \tag{22.55}$$

其中 min 按分量取，它为零当且仅当式 (22.52)成立。式中的第二项对应恒等式 (22.44)，第一项不会因为内层解得准而自动变小，这一点和二次罚相同。

能保证什么 ALM 的保证分成三个层次，所需条件依次不同。先证明凸问题的情形，证明本身也说明了 ρ 为什么影响外层。

定理 22.19 凸问题的固定参数收敛 设 f 是适当、闭的凸函数，$\boldsymbol{h}(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}$，存在最优解和最优乘子 $\boldsymbol{\nu}^\star$，且强对偶成立。设 $\rho > 0$ 固定，各子问题的全局最小点存在且精确求解，$\boldsymbol{s}^{(t)} = \boldsymbol{h}(\boldsymbol{x}^{(t)})$。则

$$\sum_{t \ge 1} \rho^2 \|\boldsymbol{s}^{(t)}\|_2^2 \le \|\boldsymbol{\nu}^{(0)} - \boldsymbol{\nu}^\star\|_2^2, \tag{22.56}$$

并且 $\boldsymbol{h}(\boldsymbol{x}^{(t)}) \to \boldsymbol{0}$，$q(\boldsymbol{\nu}^{(t)}) \to d^\star$，$f(\boldsymbol{x}^{(t)}) \to f^\star$。

证明 记 $\boldsymbol{\nu} = \boldsymbol{\nu}^{(t-1)}$，$\boldsymbol{\nu}^+ = \boldsymbol{\nu}^{(t)}$，$\boldsymbol{s}^+ = \boldsymbol{s}^{(t)}$。由定理 22.17，$\boldsymbol{s}^+$ 是 q 在 $\boldsymbol{\nu}^+$ 处的超梯度。在式 (22.30)中取比较点 $\boldsymbol{\nu}^\star$，得到

$$q(\boldsymbol{\nu}^\star) \le q(\boldsymbol{\nu}^+) + \langle \boldsymbol{s}^+, \boldsymbol{\nu}^\star - \boldsymbol{\nu}^+ \rangle.$$

$\boldsymbol{\nu}^\star$ 是 q 的最大点，所以 $q(\boldsymbol{\nu}^+) \le q(\boldsymbol{\nu}^\star)$，上式给出

$$\langle \boldsymbol{s}^+, \boldsymbol{\nu}^+ - \boldsymbol{\nu}^\star \rangle \le 0.$$

现在把 $\boldsymbol{\nu} = \boldsymbol{\nu}^+ - \rho \boldsymbol{s}^+$ 代入 $\|\boldsymbol{\nu} - \boldsymbol{\nu}^\star\|_2^2$ 并展开：

$$\|\boldsymbol{\nu} - \boldsymbol{\nu}^\star\|_2^2 = \|\boldsymbol{\nu}^+ - \boldsymbol{\nu}^\star\|_2^2 - 2\rho \langle \boldsymbol{s}^+, \boldsymbol{\nu}^+ - \boldsymbol{\nu}^\star \rangle + \rho^2 \|\boldsymbol{s}^+\|_2^2.$$

中间项非负，舍去后得到

$$\|\boldsymbol{\nu}^+ - \boldsymbol{\nu}^\star\|_2^2 + \rho^2 \|\boldsymbol{s}^+\|_2^2 \le \|\boldsymbol{\nu} - \boldsymbol{\nu}^\star\|_2^2.$$

对 t 求和裂项，即得式 (22.56)，于是 $\boldsymbol{s}^{(t)} \to \boldsymbol{0}$，且 $\boldsymbol{\nu}^{(t)}$ 有界。

再由第一个不等式，

$$0 \le d^\star - q(\boldsymbol{\nu}^+) \le \langle \boldsymbol{s}^+, \boldsymbol{\nu}^\star - \boldsymbol{\nu}^+ \rangle \le \|\boldsymbol{s}^+\|_2 \|\boldsymbol{\nu}^\star - \boldsymbol{\nu}^+\|_2 \to 0.$$

最后，由定理 22.17，$\boldsymbol{x}^{(t)}$ 是 $\mathcal{L}(\cdot, \boldsymbol{\nu}^{(t)})$ 的全局最小点，所以

$$f(\boldsymbol{x}^{(t)}) = q(\boldsymbol{\nu}^{(t)}) - \langle \boldsymbol{\nu}^{(t)}, \boldsymbol{s}^{(t)} \rangle,$$

右边趋于 $d^\star = f^\star$。 ■

式 (22.56)中的 ρ^2 说明，ρ 越大，残差平方的总和越小，外层越快。定理既不要求 ρ 放大，也不要求 f 可微，并且 $\boldsymbol{x}^{(t)}$ 本身不一定收敛，f 不强凸时子问题的解可以不唯一。

非凸问题只有局部结论。设 $(\boldsymbol{x}^\star,\boldsymbol{\nu}^\star)$ 满足 KKT 条件，LICQ 和二阶充分条件成立。那么存在 $\bar\rho$，当 $\rho\ge\bar\rho$ 时，从足够接近 $\boldsymbol{\nu}^\star$ 的乘子出发，取 $\mathcal{L}_\rho$ 在 $\boldsymbol{x}^\star$ 附近的局部最小点，乘子序列线性收敛到 $\boldsymbol{\nu}^\star$，压缩因子约为 $O(1/\rho)$。这一结论的证明需要对驻定方程应用隐函数定理，篇幅较长，读者可查阅 Nocedal 和 Wright 的著作[1]。，它的机制和式 (22.49)相同。

全局层次的结果最弱。若每个子问题只解到近似驻点，乘子保持有界（常把估计截断在一个大盒子里），可以证明聚点要么是约束违规量的驻点，要么在相应约束资格下是 KKT 点；和定理 22.5的结论是同一类型。只有每个子问题都取全局最小点，才能得到全局最优的结论，非凸问题通常做不到。下表把三个层次放在一起。

情形	主要条件	结论
凸，固定 ρ	强对偶，子问题精确	残差趋零，目标值收敛
非凸，局部	LICQ，二阶充分，$\rho\ge\bar\rho$	乘子局部线性收敛
非凸，全局策略	近似驻点，乘子有界	聚点为不可行驻点或 KKT 点

表 22.4　ALM 的三层保证。下面一行不能推出上面两行的结论。

22.5 交替方向乘子法（ADMM）

ALM 的子问题比对偶上升的子问题难的地方，在于平方项把各块耦合了。于是要问：当目标由两块组成，能否既保留乘子带来的稳定性，又把两块分开计算？本节的问题形式是

$$\min_{\boldsymbol{x},\boldsymbol{z}}\ f(\boldsymbol{x})+g(\boldsymbol{z})\qquad\text{s.t.}\qquad \boldsymbol{A}\boldsymbol{x}+\boldsymbol{B}\boldsymbol{z}=\boldsymbol{c},\tag{22.57}$$

其中 $\boldsymbol{x}\in\mathbb{R}^n$，$\boldsymbol{z}\in\mathbb{R}^l$，$\boldsymbol{A}\in\mathbb{R}^{p\times n}$，$\boldsymbol{B}\in\mathbb{R}^{p\times l}$，$\boldsymbol{c}\in\mathbb{R}^p$。这里的 g 是第二块目标，不是不等式约束。对应的增广 Lagrange 函数是

$$\mathcal{L}_\rho(\boldsymbol{x},\boldsymbol{z},\boldsymbol{\nu})=f(\boldsymbol{x})+g(\boldsymbol{z})+\langle\boldsymbol{\nu},\boldsymbol{A}\boldsymbol{x}+\boldsymbol{B}\boldsymbol{z}-\boldsymbol{c}\rangle+\frac{\rho}{2}\|\boldsymbol{A}\boldsymbol{x}+\boldsymbol{B}\boldsymbol{z}-\boldsymbol{c}\|_2^2.\tag{22.58}$$

平方项破坏了可分性　对偶分解能并行，靠的是 Lagrange 函数按块可分。增广函数的平方项里有交叉项 $\rho\langle\boldsymbol{A}\boldsymbol{x},\boldsymbol{B}\boldsymbol{z}\rangle$，可分性被破坏。ALM 只能把 $(\boldsymbol{x},\boldsymbol{z})$ 联合起来最小化，即使 f 和 g 各自都很简单。

交替方向乘子法（alternating direction method of multipliers，ADMM）的想法是：不把子问题解到最优，只把 $\boldsymbol{x}$ 和 $\boldsymbol{z}$ 各自更新一次，然后立即更新乘子。

这个想法要付代价。用二元例说明，把它看成 $f(x)=\frac12x^2$，$g(z)=\frac32z^2$，$x+z=4$，$\rho=1.5$，$\nu=0$。联合最小化 $\mathcal{L}_\rho$ 得到式 (22.42)，即 $(x,z)=(2,\frac23)$。

22.1 二次惩罚法
22.2 精确惩罚法
22.3 对偶上升
22.4 增广 Lagrange 法（ALM）
22.5 交替方向乘子法（ADMM）
22.5.1 两块交替更新
22.5.2 原始与对偶残差
22.5.3 收敛与实现
22.6 方法比较与计算成本
22.7 本章小结

[1] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

22.1 二次惩罚法
22.2 精确惩罚法
22.3 对偶上升
22.4 增广 Lagrange 法（ALM）
22.5 交替方向乘子法（ADMM）
22.5.1 两块交替更新
22.5.2 原始与对偶残差
22.5.3 收敛与实现
22.6 方法比较与计算成本
22.7 本章小结

从 $(0,0)$ 开始交替一次：先固定 $z=0$，对 x 最小化，$x=\frac{\rho\cdot 4}{1+\rho}=2.4$；再固定 $x=2.4$，对 z 最小化，$z=\frac{\rho(4-2.4)}{3+\rho}=\frac{8}{15}$。结果是 $(2.4,\frac{8}{15})$，与联合解 $(2,\frac{2}{3})$ 不同。

图 22.18(a) 画出了这两步：黄色折线先水平走，再竖直走，两步都只顾自己的方向，没有到达碗底。一次交替扫过两块，不等于把子问题解到最优，所以不能把 ALM 的结论直接搬过来。(b) 是多轮的路径，ADMM 走的是折线，ALM 走的是直线，两者最后都到达红点。

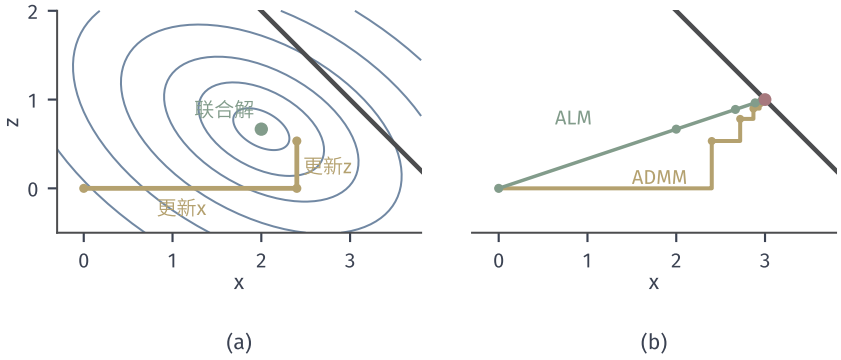


图 22.18 二元例上 ADMM 的两块交替更新，$\rho=1.5$。深灰直线是约束。(a) 蓝线是 $\nu=0$ 时增广函数的等高线，绿点是联合最小点 $(2,\frac{2}{3})$，黄色折线是从原点出发的一次交替，停在 $(2.4,\frac{8}{15})$。(b) 绿线是 ALM 每轮的联合解，黄线是 ADMM 的折线路径，红点是解 $(3,1)$。

22.5.1 两块交替更新

主要思想 每轮按固定的顺序做三步，后一步使用前一步刚得到的结果，如图 22.19所示：

$$\begin{aligned}\boldsymbol{x}^{(t+1)} &\in \arg\min_{\boldsymbol{x}} \mathcal{L}_\rho(\boldsymbol{x},\boldsymbol{z}^{(t)},\boldsymbol{\nu}^{(t)}),\\ \boldsymbol{z}^{(t+1)} &\in \arg\min_{\boldsymbol{z}} \mathcal{L}_\rho(\boldsymbol{x}^{(t+1)},\boldsymbol{z},\boldsymbol{\nu}^{(t)}),\\ \boldsymbol{\nu}^{(t+1)} &= \boldsymbol{\nu}^{(t)}+\rho\big(\boldsymbol{A}\boldsymbol{x}^{(t+1)}+\boldsymbol{B}\boldsymbol{z}^{(t+1)}-\boldsymbol{c}\big).\end{aligned} \tag{22.59}$$

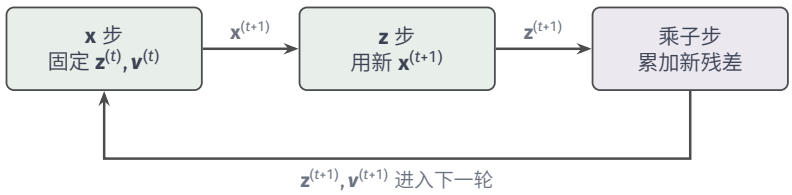


图 22.19 ADMM 一轮的三步。绿框是两个原始变量的最小化，后一块使用前一块的新值；紫框按新残差累加乘子。与 ALM 的区别在于 $\boldsymbol{x}$ 和 $\boldsymbol{z}$ 不联合求解。

这和第 12章的分块最小化很像：在固定的目标上逐块求最小。两者的区别在于这里有线性耦合约束，单纯的分块下降可能卡在不是解的点上，ADMM 靠乘子一步把约束信息累加进下一轮。

缩放乘子　把乘子除以 ρ，公式会简短很多。记残差 $\boldsymbol{r} = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{B}\boldsymbol{z} - \boldsymbol{c}$，配方得

$$\langle \boldsymbol{\nu}, \boldsymbol{r} \rangle + \frac{\rho}{2}\|\boldsymbol{r}\|_2^2 = \frac{\rho}{2}\|\boldsymbol{r} + \boldsymbol{u}\|_2^2 - \frac{\rho}{2}\|\boldsymbol{u}\|_2^2, \qquad \boldsymbol{u} = \frac{\boldsymbol{\nu}}{\rho}.$$

$\boldsymbol{u}$ 称为**缩放乘子**（scaled dual variable）。式 (22.59)写成缩放形式是

$$\begin{aligned} \boldsymbol{x}^{(t+1)} &\in \arg\min_{\boldsymbol{x}} \; f(\boldsymbol{x}) + \frac{\rho}{2}\|\boldsymbol{A}\boldsymbol{x} + \boldsymbol{B}\boldsymbol{z}^{(t)} - \boldsymbol{c} + \boldsymbol{u}^{(t)}\|_2^2, \\ \boldsymbol{z}^{(t+1)} &\in \arg\min_{\boldsymbol{z}} \; g(\boldsymbol{z}) + \frac{\rho}{2}\|\boldsymbol{A}\boldsymbol{x}^{(t+1)} + \boldsymbol{B}\boldsymbol{z} - \boldsymbol{c} + \boldsymbol{u}^{(t)}\|_2^2, \\ \boldsymbol{u}^{(t+1)} &= \boldsymbol{u}^{(t)} + \boldsymbol{A}\boldsymbol{x}^{(t+1)} + \boldsymbol{B}\boldsymbol{z}^{(t+1)} - \boldsymbol{c}. \end{aligned} \tag{22.60}$$

两种写法完全等价。缩放乘子就是残差的累加和，这是它最直观的含义：$\boldsymbol{u}^{(t)}$ 记录到目前为止累计的残差。

套索问题的拆分　ADMM 的用处是把一个有结构的问题拆成两个容易的问题。第 11章的套索问题是

$$\min_{\boldsymbol{x}} \; \frac{1}{2}\|\boldsymbol{D}\boldsymbol{x} - \boldsymbol{y}\|_2^2 + \gamma\|\boldsymbol{x}\|_1, \tag{22.61}$$

其中 $\boldsymbol{D} \in \mathbb{R}^{N\times n}$，$\gamma > 0$。把变量复制一份，让 f 负责最小二乘项 $\frac{1}{2}\|\boldsymbol{D}\boldsymbol{x}-\boldsymbol{y}\|_2^2$，$g$ 负责 $\gamma\|\boldsymbol{z}\|_1$，并加上约束 $\boldsymbol{x} - \boldsymbol{z} = \boldsymbol{0}$。这对应 $\boldsymbol{A} = \boldsymbol{I}$，$\boldsymbol{B} = -\boldsymbol{I}$，$\boldsymbol{c} = \boldsymbol{0}$。

把 f 代入式 (22.60)的第一行，这是一个二次子问题，解为

$$\boldsymbol{x}^{(t+1)} = (\boldsymbol{D}^{\top}\boldsymbol{D} + \rho\boldsymbol{I})^{-1}\big(\boldsymbol{D}^{\top}\boldsymbol{y} + \rho(\boldsymbol{z}^{(t)} - \boldsymbol{u}^{(t)})\big). \tag{22.62}$$

第二行是 $\gamma\|\boldsymbol{z}\|_1$ 加上一个以 $\boldsymbol{x}^{(t+1)} + \boldsymbol{u}^{(t)}$ 为中心的二次项，按坐标可分，由软阈值给出：

$$\boldsymbol{z}^{(t+1)} = S_{\gamma/\rho}\big(\boldsymbol{x}^{(t+1)} + \boldsymbol{u}^{(t)}\big), \qquad S_{\tau}(a) = \operatorname{sign}(a)\max\{|a| - \tau, 0\}. \tag{22.63}$$

第三行是缩放乘子的累加：

$$\boldsymbol{u}^{(t+1)} = \boldsymbol{u}^{(t)} + \boldsymbol{x}^{(t+1)} - \boldsymbol{z}^{(t+1)}. \tag{22.64}$$

二次子问题只含 f，软阈值只含 g，这样两部分结构都得到了利用。

计算过程 用第 11章的小例子演示，数据是

$$\boldsymbol{D} = \begin{pmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{pmatrix}, \qquad \boldsymbol{y} = \begin{pmatrix} 3 \\ 2 \\ -1 \end{pmatrix}, \qquad \gamma = 1.$$

这个问题的解是 $\boldsymbol{x}^\star = (2, 0)$，由它算出乘子

$$\boldsymbol{v}^\star = \boldsymbol{D}^\top(\boldsymbol{y} - \boldsymbol{D}\boldsymbol{x}^\star) = (1, 0).$$

变量

- $\boldsymbol{x}^{(t)}, \boldsymbol{z}^{(t)} \in \mathbb{R}^n$：两块原始变量。例中 $n = 2$。
- $\boldsymbol{u}^{(t)} \in \mathbb{R}^n$：缩放乘子。
- $(\boldsymbol{D}^\top\boldsymbol{D} + \rho\boldsymbol{I})^{-1}$：只需计算一次的矩阵分解。

初始化 取 $\boldsymbol{z}^{(0)}$、$\boldsymbol{u}^{(0)}$ 和 ρ。例中 $\boldsymbol{z}^{(0)} = \boldsymbol{u}^{(0)} = \boldsymbol{0}$，$\rho = 1$，并预先算出

$$\boldsymbol{D}^\top\boldsymbol{y} = \begin{pmatrix} 5 \\ 2 \end{pmatrix}, \qquad (\boldsymbol{D}^\top\boldsymbol{D} + \boldsymbol{I})^{-1} = \frac{1}{8}\begin{pmatrix} 3 & -1 \\ -1 & 3 \end{pmatrix}.$$

每轮更新

1. 由式 (22.62)算 $\boldsymbol{x}^{(t+1)}$。例中第一轮

$$\boldsymbol{x}^{(1)} = \frac{1}{8}\begin{pmatrix} 3 & -1 \\ -1 & 3 \end{pmatrix}\begin{pmatrix} 5 \\ 2 \end{pmatrix} = \begin{pmatrix} 1.625 \\ 0.125 \end{pmatrix}.$$

2. 由式 (22.63)算 $\boldsymbol{z}^{(t+1)}$，阈值是 $\gamma/\rho = 1$。例中第一轮

$$\boldsymbol{z}^{(1)} = S_1(1.625,\ 0.125) = (0.625,\ 0).$$

3. 由式 (22.64)累加残差。例中第一轮

$$\boldsymbol{u}^{(1)} = (1,\ 0.125).$$

第二轮中，式 (22.62)的右端向量是 $(4.625, 1.875)$，得到

$$\boldsymbol{x}^{(2)} = (1.5,\ 0.125), \qquad \boldsymbol{z}^{(2)} = (1.5,\ 0), \qquad \boldsymbol{u}^{(2)} = (1,\ 0.25).$$

第三轮中，右端向量是 $(5.5, 1.75)$，得到

$$\boldsymbol{x}^{(3)} = (1.84375,\ -0.03125), \quad \boldsymbol{z}^{(3)} = (1.84375,\ 0), \quad \boldsymbol{u}^{(3)} = (1,\ 0.21875).$$

22.1 二次惩罚法
22.2 精确惩罚法
22.3 对偶上升
22.4 增广 Lagrange 法（ALM）
22.5 交替方向乘子法（ADMM）
22.5.1 两块交替更新
22.5.2 原始与对偶残差
22.5.3 收敛与实现
22.6 方法比较与计算成本
22.7 本章小结

结束条件由下一小节的残差给出。例中 $\boldsymbol{z}^{(t)}$ 从第一轮起就有第二个分量恰好为零，这是软阈值带来的。而 $\boldsymbol{x}^{(t)}$ 的第二个分量不为零，只有极限才为零。继续迭代，24 轮后两种残差都小于 10^{-6}，最终得到 $\boldsymbol{z}\approx(2,0)$，$\boldsymbol{u}\approx(1,0)$，与上面的 $\boldsymbol{x}^\star$ 和 $\boldsymbol{\nu}^\star$ 一致。

22.5.2 原始与对偶残差

两类残差的来历 判断 ADMM 是否收敛，要回到 KKT 条件。问题 (22.57) 的 KKT 条件有三条：

$$\boldsymbol{A}\boldsymbol{x}^\star+\boldsymbol{B}\boldsymbol{z}^\star=\boldsymbol{c},\qquad \boldsymbol{0}\in\partial f(\boldsymbol{x}^\star)+\boldsymbol{A}^{\top}\boldsymbol{\nu}^\star,\qquad \boldsymbol{0}\in\partial g(\boldsymbol{z}^\star)+\boldsymbol{B}^{\top}\boldsymbol{\nu}^\star. \tag{22.65}$$

第一条对应**原始残差**（primal residual）：

$$\boldsymbol{r}^{(t+1)}=\boldsymbol{A}\boldsymbol{x}^{(t+1)}+\boldsymbol{B}\boldsymbol{z}^{(t+1)}-\boldsymbol{c}. \tag{22.66}$$

它度量约束违规。

后两条要看子问题的最优性条件。$\boldsymbol{z}^{(t+1)}$ 最小化 $\mathcal{L}_\rho(\boldsymbol{x}^{(t+1)},\cdot,\boldsymbol{\nu}^{(t)})$，所以

$$\boldsymbol{0}\in\partial g(\boldsymbol{z}^{(t+1)})+\boldsymbol{B}^{\top}\boldsymbol{\nu}^{(t)}+\rho\boldsymbol{B}^{\top}\boldsymbol{r}^{(t+1)}=\partial g(\boldsymbol{z}^{(t+1)})+\boldsymbol{B}^{\top}\boldsymbol{\nu}^{(t+1)}.$$

第三条 KKT 条件每一轮都自动成立。这也说明了乘子步长取成 ρ 的原因，和式 (22.44) 是同一个道理。

$\boldsymbol{x}^{(t+1)}$ 的最优性条件里，用的是旧的 $\boldsymbol{z}^{(t)}$：

$$\boldsymbol{0}\in\partial f(\boldsymbol{x}^{(t+1)})+\boldsymbol{A}^{\top}\boldsymbol{\nu}^{(t)}+\rho\boldsymbol{A}^{\top}\big(\boldsymbol{A}\boldsymbol{x}^{(t+1)}+\boldsymbol{B}\boldsymbol{z}^{(t)}-\boldsymbol{c}\big).$$

用乘子更新式把 $\boldsymbol{\nu}^{(t)}$ 换成 $\boldsymbol{\nu}^{(t+1)}$，整理得到

$$\rho\boldsymbol{A}^{\top}\boldsymbol{B}(\boldsymbol{z}^{(t+1)}-\boldsymbol{z}^{(t)})\in\partial f(\boldsymbol{x}^{(t+1)})+\boldsymbol{A}^{\top}\boldsymbol{\nu}^{(t+1)}. \tag{22.67}$$

左边的向量就是第二条 KKT 条件还差的部分，这是**对偶残差**（dual residual）：

$$\boldsymbol{s}^{(t+1)}=\rho\boldsymbol{A}^{\top}\boldsymbol{B}(\boldsymbol{z}^{(t+1)}-\boldsymbol{z}^{(t)}). \tag{22.68}$$

对偶残差的来源，是 $\boldsymbol{x}$ 更新时用了 $\boldsymbol{z}$ 的旧值。如果 $\boldsymbol{x},\boldsymbol{z}$ 是联合求解的，它就恒为零，这正是 ALM 没有这一项的原因。

例中 $\boldsymbol{A}=\boldsymbol{I}$，$\boldsymbol{B}=-\boldsymbol{I}$，所以

$$\|\boldsymbol{r}^{(t)}\|_2=\|\boldsymbol{x}^{(t)}-\boldsymbol{z}^{(t)}\|_2,\qquad \|\boldsymbol{s}^{(t)}\|_2=\rho\|\boldsymbol{z}^{(t)}-\boldsymbol{z}^{(t-1)}\|_2.$$

上面三轮的数值是

$$\|\boldsymbol{r}^{(1)}\|_2 \approx 1.008, \qquad \|\boldsymbol{r}^{(2)}\|_2 = 0.125, \qquad \|\boldsymbol{r}^{(3)}\|_2 \approx 0.031,$$

$$\|\boldsymbol{s}^{(1)}\|_2 = 0.625, \qquad \|\boldsymbol{s}^{(2)}\|_2 = 0.875, \qquad \|\boldsymbol{s}^{(3)}\|_2 \approx 0.344.$$

可见两个残差并不同步，第二轮原始残差下降，对偶残差反而上升。只看其中一个会误判。图 22.20(a) 是完整的残差曲线。

停止准则 两个残差都小才算结束。残差的量级依赖数据的量级，所以常用绝对容差 ε_{abs} 和相对容差 ε_{rel} 的组合：

$$\begin{aligned} \|\boldsymbol{r}^{(t)}\|_2 &\le \sqrt{p}\,\varepsilon_{\text{abs}} + \varepsilon_{\text{rel}} \max\{\|\boldsymbol{A}\boldsymbol{x}^{(t)}\|_2, \|\boldsymbol{B}\boldsymbol{z}^{(t)}\|_2, \|\boldsymbol{c}\|_2\}, \\ \|\boldsymbol{s}^{(t)}\|_2 &\le \sqrt{n}\,\varepsilon_{\text{abs}} + \varepsilon_{\text{rel}} \|\boldsymbol{A}^{\top}\boldsymbol{\nu}^{(t)}\|_2. \end{aligned} \tag{22.69}$$

绝对容差防止目标为零附近时相对准则失效，$\sqrt{p}$ 和 $\sqrt{n}$ 让绝对容差按每个分量计。

罚参数的影响与调整 ρ 在两个残差之间做权衡。ρ 大，约束被更用力地压住，原始残差小；可 $\boldsymbol{s}$ 正比于 ρ，对偶残差变大。ρ 小时情况相反。图 22.20(b) 是轮数随 ρ 变化的曲线，有一个相当宽的最佳区间，两端都很慢。

一种常见的启发式规则是让两个残差保持同一量级：

$$\rho^{(t+1)} = \begin{cases} 2\rho^{(t)}, & \|\boldsymbol{r}^{(t)}\|_2 > 10\|\boldsymbol{s}^{(t)}\|_2, \\ \rho^{(t)}/2, & \|\boldsymbol{s}^{(t)}\|_2 > 10\|\boldsymbol{r}^{(t)}\|_2, \\ \rho^{(t)}, & \text{其他}. \end{cases} \tag{22.70}$$

这称为**残差平衡**（residual balancing）。改变 ρ 时要特别注意缩放乘子。未缩放的 $\boldsymbol{\nu}$ 不变，所以 $\boldsymbol{u} = \boldsymbol{\nu}/\rho$ 必须同步换算：

$$\boldsymbol{u} \leftarrow \frac{\rho^{(t)}}{\rho^{(t+1)}}\boldsymbol{u}. \tag{22.71}$$

忘记换算，相当于悄悄改变了乘子，迭代会被打乱。此外，ρ 变化后需要重新分解矩阵，下面的收敛定理也只对固定的 ρ 成立，实际中常在迭代若干轮后固定 ρ。

22.1 二次惩罚法
22.2 精确惩罚法
22.3 对偶上升
22.4 增广 Lagrange 法（ALM）
22.5 交替方向乘子法（ADMM）
22.5.1 两块交替更新
22.5.2 原始与对偶残差
22.5.3 收敛与实现
22.6 方法比较与计算成本
22.7 本章小结

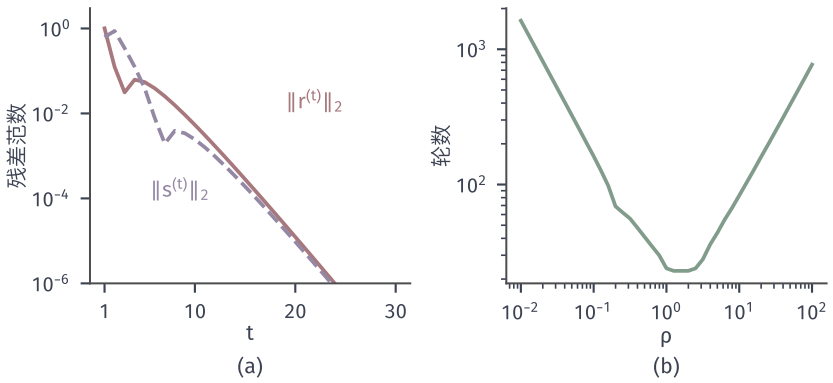


图 22.20 小例子上的 ADMM。(a) 半对数坐标，$\rho = 1$，红线是原始残差，紫色虚线是对偶残差。(b) 双对数坐标，两个残差都小于 10^{-6} 所需的轮数随 ρ 的变化。两端都慢，中间有一段较宽的平坦区域。

22.5.3 收敛与实现

收敛定理 ADMM 的步子不是 ALM 的精确子问题，上一节的定理不能直接用，需要一个专门的证明。证明的想法是构造一个 Lyapunov 函数，它把乘子误差和 $\boldsymbol{z}$ 的误差放在一起，每一轮都下降。

定理 22.20 两块 ADMM 的收敛 设 f, g 是适当、闭的凸函数，固定 $\rho > 0$，式 (22.59)的两个子问题的最小点存在并精确求解。设 $\mathcal{L}_0$ 有鞍点 $(\boldsymbol{x}^\star, \boldsymbol{z}^\star, \boldsymbol{\nu}^\star)$，记 $p^\star = f(\boldsymbol{x}^\star) + g(\boldsymbol{z}^\star)$，$p^{(t)} = f(\boldsymbol{x}^{(t)}) + g(\boldsymbol{z}^{(t)})$，并记

$$V^{(t)} = \frac{1}{\rho}\|\boldsymbol{\nu}^{(t)} - \boldsymbol{\nu}^\star\|_2^2 + \rho\|\boldsymbol{B}(\boldsymbol{z}^{(t)} - \boldsymbol{z}^\star)\|_2^2. \tag{22.72}$$

则 $t \geq 1$ 时

$$V^{(t+1)} \leq V^{(t)} - \rho\|\boldsymbol{r}^{(t+1)}\|_2^2 - \rho\|\boldsymbol{B}(\boldsymbol{z}^{(t+1)} - \boldsymbol{z}^{(t)})\|_2^2, \tag{22.73}$$

并且 $\boldsymbol{r}^{(t)} \to \boldsymbol{0}$，$\boldsymbol{s}^{(t)} \to \boldsymbol{0}$，$p^{(t)} \to p^\star$。若 $\boldsymbol{A}, \boldsymbol{B}$ 还列满秩，则 $\boldsymbol{x}^{(t)}, \boldsymbol{z}^{(t)}, \boldsymbol{\nu}^{(t)}$ 都收敛，其极限构成一个鞍点。

证明 记 $\boldsymbol{r} = \boldsymbol{r}^{(t+1)}$，$\boldsymbol{w} = \boldsymbol{B}(\boldsymbol{z}^{(t+1)} - \boldsymbol{z}^{(t)})$。证明分四步。

第一步，用鞍点给出一侧不等式。鞍点满足

$$\mathcal{L}_0(\boldsymbol{x}^\star, \boldsymbol{z}^\star, \boldsymbol{\nu}^\star) \leq \mathcal{L}_0(\boldsymbol{x}^{(t+1)}, \boldsymbol{z}^{(t+1)}, \boldsymbol{\nu}^\star),$$

再用 $\boldsymbol{A}\boldsymbol{x}^\star + \boldsymbol{B}\boldsymbol{z}^\star = \boldsymbol{c}$，于是

$$p^\star - p^{(t+1)} \leq \langle \boldsymbol{\nu}^\star, \boldsymbol{r} \rangle. \tag{22.74}$$

第二步，用子问题的最优性给出另一侧不等式。上一小节已经推导，$\boldsymbol{x}^{(t+1)}$ 最小化凸函数 $f(\boldsymbol{x})+\langle \boldsymbol{\nu}^{(t+1)}-\rho\boldsymbol{w}, \boldsymbol{A}\boldsymbol{x}\rangle$，$\boldsymbol{z}^{(t+1)}$ 最小化凸函数 $g(\boldsymbol{z})+\langle \boldsymbol{\nu}^{(t+1)}, \boldsymbol{B}\boldsymbol{z}\rangle$。分别在 $\boldsymbol{x}^\star$、$\boldsymbol{z}^\star$ 处比较，得到

$$f(\boldsymbol{x}^{(t+1)})+\langle \boldsymbol{\nu}^{(t+1)}-\rho\boldsymbol{w}, \boldsymbol{A}\boldsymbol{x}^{(t+1)}\rangle \le f(\boldsymbol{x}^\star)+\langle \boldsymbol{\nu}^{(t+1)}-\rho\boldsymbol{w}, \boldsymbol{A}\boldsymbol{x}^\star\rangle,$$

$$g(\boldsymbol{z}^{(t+1)})+\langle \boldsymbol{\nu}^{(t+1)}, \boldsymbol{B}\boldsymbol{z}^{(t+1)}\rangle \le g(\boldsymbol{z}^\star)+\langle \boldsymbol{\nu}^{(t+1)}, \boldsymbol{B}\boldsymbol{z}^\star\rangle.$$

两式相加。由 $\boldsymbol{A}\boldsymbol{x}^\star+\boldsymbol{B}\boldsymbol{z}^\star=\boldsymbol{c}$，有

$$\boldsymbol{A}(\boldsymbol{x}^{(t+1)}-\boldsymbol{x}^\star)+\boldsymbol{B}(\boldsymbol{z}^{(t+1)}-\boldsymbol{z}^\star)=\boldsymbol{r},$$

所以含 $\boldsymbol{\nu}^{(t+1)}$ 的项合并成 $\langle \boldsymbol{\nu}^{(t+1)}, \boldsymbol{r}\rangle$。再把 $\boldsymbol{A}(\boldsymbol{x}^{(t+1)}-\boldsymbol{x}^\star)$ 换成 $\boldsymbol{r}-\boldsymbol{B}(\boldsymbol{z}^{(t+1)}-\boldsymbol{z}^\star)$，得到

$$p^{(t+1)}-p^\star \le -\langle \boldsymbol{\nu}^{(t+1)}, \boldsymbol{r}\rangle+\rho\langle \boldsymbol{w}, \boldsymbol{r}-\boldsymbol{B}(\boldsymbol{z}^{(t+1)}-\boldsymbol{z}^\star)\rangle. \tag{22.75}$$

第三步，推导下降不等式。式 (22.74)与式 (22.75)相加，左边为零，两边乘 2 并移项，得到

$$2\langle \boldsymbol{\nu}^{(t+1)}-\boldsymbol{\nu}^\star, \boldsymbol{r}\rangle-2\rho\langle \boldsymbol{w}, \boldsymbol{r}\rangle+2\rho\langle \boldsymbol{w}, \boldsymbol{B}(\boldsymbol{z}^{(t+1)}-\boldsymbol{z}^\star)\rangle \le 0.$$

第一项用 $\boldsymbol{\nu}^{(t+1)}=\boldsymbol{\nu}^{(t)}+\rho\boldsymbol{r}$ 改写，按乘子距离的平方差展开：

$$2\langle \boldsymbol{\nu}^{(t+1)}-\boldsymbol{\nu}^\star, \boldsymbol{r}\rangle=\frac{1}{\rho}\Big(\|\boldsymbol{\nu}^{(t+1)}-\boldsymbol{\nu}^\star\|_2^2-\|\boldsymbol{\nu}^{(t)}-\boldsymbol{\nu}^\star\|_2^2\Big)+\rho\|\boldsymbol{r}\|_2^2.$$

第三项要用下面的恒等式：

$$2\langle \boldsymbol{a}-\boldsymbol{b}, \boldsymbol{a}\rangle=\|\boldsymbol{a}\|_2^2-\|\boldsymbol{b}\|_2^2+\|\boldsymbol{a}-\boldsymbol{b}\|_2^2.$$

取 $\boldsymbol{a}=\boldsymbol{B}(\boldsymbol{z}^{(t+1)}-\boldsymbol{z}^\star)$，$\boldsymbol{b}=\boldsymbol{B}(\boldsymbol{z}^{(t)}-\boldsymbol{z}^\star)$，此时 $\boldsymbol{a}-\boldsymbol{b}=\boldsymbol{w}$，于是

$$2\rho\langle \boldsymbol{w}, \boldsymbol{a}\rangle=\rho\|\boldsymbol{a}\|_2^2-\rho\|\boldsymbol{b}\|_2^2+\rho\|\boldsymbol{w}\|_2^2.$$

把这两式代回，合并成

$$V^{(t+1)}-V^{(t)}+\rho\|\boldsymbol{r}\|_2^2+\rho\|\boldsymbol{w}\|_2^2-2\rho\langle \boldsymbol{w}, \boldsymbol{r}\rangle \le 0.$$

只差 $\langle \boldsymbol{w}, \boldsymbol{r}\rangle$ 的符号。设 $t\ge 1$，$\boldsymbol{z}^{(t)}$ 也是上一轮的子问题解，最小化 $g(\boldsymbol{z})+\langle \boldsymbol{\nu}^{(t)}, \boldsymbol{B}\boldsymbol{z}\rangle$。把它和 $\boldsymbol{z}^{(t+1)}$ 的最优性互相比较，

$$g(\boldsymbol{z}^{(t+1)})+\langle \boldsymbol{\nu}^{(t+1)}, \boldsymbol{B}\boldsymbol{z}^{(t+1)}\rangle \le g(\boldsymbol{z}^{(t)})+\langle \boldsymbol{\nu}^{(t+1)}, \boldsymbol{B}\boldsymbol{z}^{(t)}\rangle,$$

$$g(\boldsymbol{z}^{(t)}) + \langle \boldsymbol{\nu}^{(t)}, \boldsymbol{B}\boldsymbol{z}^{(t)} \rangle \le g(\boldsymbol{z}^{(t+1)}) + \langle \boldsymbol{\nu}^{(t)}, \boldsymbol{B}\boldsymbol{z}^{(t+1)} \rangle .$$

相加后，g 的项全部消去，剩下

$$\langle \boldsymbol{\nu}^{(t+1)} - \boldsymbol{\nu}^{(t)}, \boldsymbol{w} \rangle \le 0,$$

也就是 $\rho\langle \boldsymbol{r}, \boldsymbol{w} \rangle \le 0$。于是 $-2\rho\langle \boldsymbol{w}, \boldsymbol{r} \rangle \ge 0$，舍去后即得式 (22.73)。

第四步，取极限。对式 (22.73)求和，$\sum_t \|\boldsymbol{r}^{(t)}\|_2^2$ 和 $\sum_t \|\boldsymbol{w}\|_2^2$ 都有限，所以 $\boldsymbol{r}^{(t)} \to \boldsymbol{0}$，$\boldsymbol{B}(\boldsymbol{z}^{(t+1)} - \boldsymbol{z}^{(t)}) \to \boldsymbol{0}$，进而 $\boldsymbol{s}^{(t)} \to \boldsymbol{0}$。同时 $V^{(t)}$ 有界，所以 $\boldsymbol{\nu}^{(t)}$ 和 $\boldsymbol{B}\boldsymbol{z}^{(t)}$ 都有界。式 (22.75)的右边因此趋于零，式 (22.74)的右边也趋于零，夹逼得 $p^{(t)} \to p^\star$。

最后设 $\boldsymbol{A}, \boldsymbol{B}$ 列满秩。$\boldsymbol{B}\boldsymbol{z}^{(t)}$ 有界推出 $\boldsymbol{z}^{(t)}$ 有界，再由 $\boldsymbol{r}^{(t)} \to \boldsymbol{0}$ 推出 $\boldsymbol{A}\boldsymbol{x}^{(t)}$ 有界，从而 $\boldsymbol{x}^{(t)}$ 有界。

取一个收敛子列，极限记为 $(\hat{\boldsymbol{x}}, \hat{\boldsymbol{z}}, \hat{\boldsymbol{\nu}})$。在 $\boldsymbol{r} = \boldsymbol{0}$、最优性包含式 (22.67)和 $\boldsymbol{z}$ 的最优性条件里取极限（闭凸函数的次微分图像是闭的），可知极限满足 KKT 条件 (22.65)，所以它是鞍点。

式 (22.73)对任意鞍点成立。取这个鞍点作为比较点，$V^{(t)}$ 单调不增且沿子列趋于零，所以整列趋于零。再由列满秩，$\boldsymbol{x}^{(t)}, \boldsymbol{z}^{(t)}, \boldsymbol{\nu}^{(t)}$ 整列收敛。 ■

定理的各部分有不同的强度。残差和目标值的收敛只需要鞍点存在。在没有列满秩的一般情形下，$\boldsymbol{\nu}^{(t)}$ 本身也收敛到某个最优乘子，这个结论可以从 ADMM 与 Douglas–Rachford 分裂的等价关系得到，证明需要算子分裂的不动点理论，篇幅较长，这里只使用结论。

原始变量的整列收敛则确实需要额外条件。$\boldsymbol{A}$ 不是列满秩时，$\boldsymbol{x}$ 可以在 $\operatorname{null}(\boldsymbol{A})$ 方向上不确定，子问题的解都不唯一，序列没有理由收敛。

实现中的计算　ADMM 每轮的代价取决于两个子问题。套索的例子中，$\boldsymbol{x}$ 更新要解以 $\boldsymbol{D}^{\top}\boldsymbol{D} + \rho\boldsymbol{I}$ 为系数的线性系统，ρ 固定时这个矩阵只需分解一次。一次 Cholesky 分解约需 $O(n^3)$ 次运算，此后每轮只需 $O(n^2)$ 次前代和回代。

当 $N \ll n$ 时，用矩阵求逆引理转化为 $N \times N$ 的系统，分解成本降为 $O(N^2 n)$。$\boldsymbol{z}$ 更新是逐坐标的软阈值，只需 $O(n)$。

分布式的场合，$\boldsymbol{x}$ 和 $\boldsymbol{z}$ 常放在不同机器上，每轮通信量是一个残差大小的向量。与联合求解的 ALM 比较，ADMM 的单轮代价低，通信轮数多。ADMM 的典型行为是前面几十轮到达中等精度，此后缓慢收敛，所以适合中等精度的问题。

22.1 二次惩罚法
22.2 精确惩罚法
22.3 对偶上升
22.4 增广 Lagrange 法（ALM）
22.5 交替方向乘子法（ADMM）
22.6 方法比较与计算成本
22.7 本章小结

子问题的精度 定理要求子问题精确求解。实际上线性系统用迭代法解，或者子问题本身没有闭式解。凸的情形下，只要各轮的误差可和，收敛结论仍然成立，证明需要把误差项带入上述下降不等式，并做累加估计。内层精度不够时，$\boldsymbol{x}$ 的最优性条件 (22.67)有一个误差项，所以对偶残差 $\boldsymbol{s}$ 不再完全反映驻定误差，需要另外监控子问题的残差。

多块与非凸 从形式上看，把两块推广到三块只是多写一行，但保证不能沿用。有一个三块的反例：

$$\min\ 0 \qquad \text{s.t.} \qquad \boldsymbol{a}_1 x_1 + \boldsymbol{a}_2 x_2 + \boldsymbol{a}_3 x_3 = \boldsymbol{0},$$

其中 $\boldsymbol{a}_1 = (1,1,1)$，$\boldsymbol{a}_2 = (1,1,2)$，$\boldsymbol{a}_3 = (1,2,2)$。系数矩阵可逆，唯一解是原点，目标是常数 0。按三块逐块更新，$\rho = 1$。数值计算给出这个线性迭代矩阵的谱半径约为 $1.028 > 1$，所以序列从几乎任何初值出发都发散。

图 22.21中，红线是三块更新的残差，一直增长；绿线把后两块合并成一块，按两块 ADMM 更新，残差下降。这个例子的目标恒为零，每个子问题都精确可解，失败的原因只在更新的结构上。

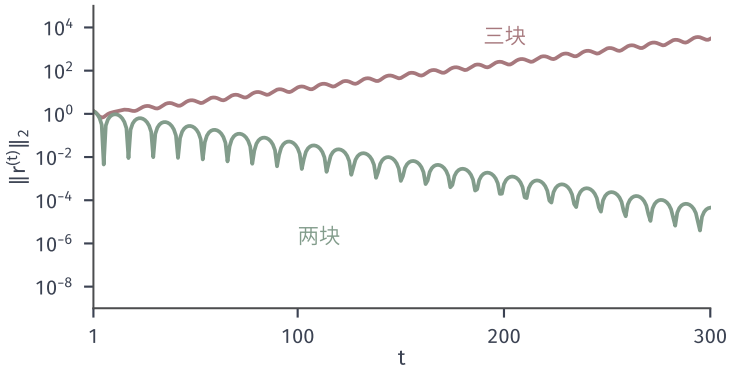


图 22.21 同一个线性系统上的三块与两块 ADMM，$\rho = 1$，半对数坐标，初值 $\boldsymbol{x}^{(0)} = (1,1,1)$，乘子初值为零。红线是逐块更新三块的残差，发散；绿线把后两块合并成一块，收敛。

非凸问题上的 ADMM 使用很广，但一般只能保证在额外的结构条件下收敛到驻点，有时需要 ρ 足够大，有时根本不收敛。一个非凸改写在形式上和 ADMM 相同，并不意味着上面的定理适用，每种情形都需要重新分析。结束时仍然要回到原约束和最优性条件上去检查。

22.6 方法比较与计算成本

本节回答一个实际问题：同一个约束问题，四种方法到底哪里不同，比较代价时应该数什么。

各方法改变了什么　四种方法都在做同一件事，把约束的信息换成原始变量子问题里的一项。它们的差别可以按三个方面读出来：给目标加了什么，乘子怎样更新，原始变量怎样求解。

方法	目标的改动	乘子	原始变量
二次罚	加平方罚	无（ρh 仅作估计）	逐轮全部求解
一次罚	加一次罚	无（门槛内隐含）	非光滑子问题
对偶上升	加线性价格	显式步	可分块，全部求解
ALM	价格加平方罚	隐式步，步长 ρ	联合求解
ADMM	价格加平方罚	步长 ρ	两块各更新一次

表 22.5　各方法的结构对照。

相同精度下的代价　比较时要固定口径。各方法的罚目标函数不同，比较目标值没有意义；ADMM 的一轮和 ALM 的一轮完成的工作也不同，比较轮数同样没有意义。合理的办法是固定同一个问题，要求达到相同的原始精度，再分别统计外层轮数、内层计算和通信。

下面用二元例，都从原点出发，要求 $|h(\boldsymbol{x})| \le 10^{-3}$。内层的梯度法取步长 $1/L$，容差为 10^{-6}，这样内层误差不干扰外层。ADMM 的两个子问题都是一元二次函数的最小化，取闭式解。

方法	外层轮数	内层梯度步	矩阵分解	最大条件数
二次罚（ρ 乘 10）	5	123443	5	15001
对偶上升（$\alpha = 0.6$）	7	162	0	3
ALM（$\rho = 1.5$）	8	230	1	3.1
ADMM（$\rho = 1.5$）	11	闭式	0	无

表 22.6　二元例中达到 $|h| \le 10^{-3}$ 的代价。“矩阵分解”指改用直接法解内层时需要的分解次数。这些数字只对这个例子有效。

表 22.6和图 22.22说明了几件事。二次罚外层轮数最少，内层步数却多出几个数量级，几乎全部花在最后两轮的病态问题上。ALM 比二次罚多几轮，却始终在解同一个良态问题。

对偶上升在这里表现很好，因为 f 是强凸的，内层矩阵的条件数只有 3，步长也事先选好了。如果把目标改成线性的，或者步长取到 1.5，它就失效了，表中的数字不能外推。ADMM 在这里每个子问题都是一元的，所以一轮很便宜，但一轮要交换一次信息。在通信比本地计算贵得多的环境中，轮数才是主要成本。

22.1 二次惩罚法
22.2 精确惩罚法
22.3 对偶上升
22.4 增广 Lagrange 法（ALM）
22.5 交替方向乘子法（ADMM）
22.6 方法比较与计算成本
22.7 本章小结

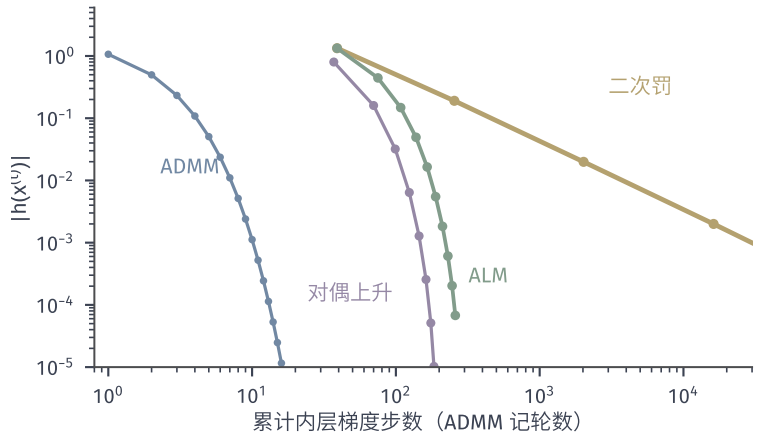


图 22.22 二元例上约束残差随累计计算量的下降，双对数坐标。黄线是二次罚，紫线是对偶上升，绿线是 ALM，横轴是累计的梯度步数（内层容差 10^{-6}）；蓝线是 ADMM，横轴是轮数，两者的单位不同，只宜比较曲线的走势。

比较时容易出错的地方 第一，不同方法的罚目标值不可比。Q_ρ、E_ρ、$\mathcal{L}_\rho$ 的数值里都混有罚项，要比较的是原目标和约束违规，或者驻定残差。

第二，只比较一次内层更新的速度会误导。一次梯度步的时间四种方法差不多，但需要多少步完全取决于子问题的条件数；对偶上升的内层便宜，可能需要更多外层轮数。

第三，精度要对等。一个方法返回约束残差 10^{-3} 的点，另一个返回 10^{-6} 的点，前者的目标值可能因为更不可行而显得更低。

第四，不同方法适用的问题不同，这个例子凸、光滑、约束线性。约束非线性时，对偶上升和 ADMM 的结论都要重新检查；目标非凸时，ALM 的局部结论才是相关的。选择方法时应先看问题的结构：约束少而目标规模大时考虑 ALM，目标和约束可分时考虑对偶分解或 ADMM，只需要中等精度且子问题便宜时考虑 ADMM，需要高精度时考虑 ALM 或者后面两章的方法。

22.7 本章小结

本章从一个问题开始：允许迭代点暂时违反约束，用什么信号把它拉回来。

惩罚方法给违规计价。二次罚光滑，但边界上没有回推的力，有限的 ρ 总留下违规，$\rho \to \infty$ 时法向曲率随之增长，子问题越来越病态。一次罚在边界上有尖角，ρ 超过最优乘子的最大绝对分量后最小点就是原问题的解，代价是目标不可微。“精确”的含义是解的对应，全局结论需要强对偶和对偶解存在，局部结论需要误差界或二阶条件。

对偶上升直接调整价格。解完 Lagrange 子问题，约束残差就是对偶函数的超梯度，目标可分时各块可以独立求解。它改进的是下界，迭代点通

常不可行，步长受限，q 不可微时单步未必上升；要得到原始解，需要平均、选解或修复，并且同时报告可行性和间隙。

增广 Lagrange 法把价格和平方罚合在一起。乘子提供大部分的力，罚项修正余下的部分，所以有限的 ρ 就够了。从对偶问题看，它是隐式的邻近点步，比显式的对偶上升稳定得多，凸问题中任何固定的 $\rho > 0$ 都收敛。代价是平方项把变量耦合起来，子问题更难。不等式要用正部形式，乘子要保持非负。

ADMM 把两块变量各更新一次，用一次乘子更新代替联合求解。这样既保留乘子的稳定性，又能分别利用两块结构，代价是出现了对偶残差。原始残差和对偶残差要一起看，ρ 改变时缩放乘子要同步换算。两块闭凸目标在鞍点存在时有收敛保证，多块或非凸的情形不能沿用。

方法	主要条件	能保证什么
二次罚	各轮全局解，$\rho \to \infty$	聚点全局最优
一次罚	强对偶，ρ 超过门槛	最小点集合相同
对偶上升	残差来自全局最小点	超梯度；凸时平均点渐近可行
ALM	凸，强对偶，固定 ρ	残差趋零，目标值收敛
ADMM	两块闭凸，鞍点存在	两种残差趋零，目标值收敛

表 22.7　本章各方法的主要条件与保证。局部结论和近似求解下的结论见各节。

几种方法结束时要做的事是一样的：回到原约束检查可行性，回到 Lagrange 函数检查驻定，有不等式时检查互补；需要全局结论时，再用对偶值或者凸性给出证书。第 23章接着处理光滑非线性约束，用局部二次模型同时更新原始变量和乘子。

23.1 局部二次模型
23.2 等式 QP 的求解
23.3 有效集法（Active-Set）
23.4 曲率的处理
23.5 更新的接受
23.6 模型的修复
23.7 收敛与计算成本
23.8 本章小结

第 23 章

序列二次规划

考虑圆周上的一个小问题：

$$\min_{\boldsymbol{x}\in\mathbb{R}^2} \; f(\boldsymbol{x}) = -x_1 - x_2 \quad \text{s.t.} \quad h(\boldsymbol{x}) = x_1^2 + x_2^2 - 2 = 0. \tag{23.1}$$

解是 $\boldsymbol{x}^\star = (1,1)^\top$。第 22章的办法是把约束折进目标，解一串无约束问题，每个无约束问题自身又要迭代很多步。第 7章的 Newton 法提示了另一条路：在当前点建一个局部模型，一步解出模型的最优步，再换一个点重建模型。

把这个想法搬到约束问题上，立刻有几个问题。约束也要进入模型，它该近似到几阶？式 (23.1)的目标是线性的，Hessian 为零，模型的曲率从哪里来？约束不止一条时，哪些不等式此刻该算数？模型给出的步不满足真实约束，也未必降低目标，又凭什么采用它？

本章按这个顺序回答。第 23.1节写出局部模型，它是一个二次规划。第 23.2节解只含等式的模型，第 23.3节处理不等式。第 23.4节讨论模型的曲率不合适时怎么办。

第 23.5节把模型的步放回原问题检验，第 23.6节处理模型本身失效或好步被误拒的情形。第 23.7节说明这些部件合起来在什么条件下收敛得快，以及每一轮要花多少计算。全章用问题 (23.1)作手算的主线。

23.1 局部二次模型

站在当前点 $\boldsymbol{x}^{(t)}$，怎样写出一个既能求解、又能代表原问题的局部模型？一般的问题写成

$$\begin{aligned} \min_{\boldsymbol{x}\in\mathbb{R}^n} \quad & f(\boldsymbol{x}) \\ \text{s.t.} \quad & g_i(\boldsymbol{x}) \le 0, \quad i = 1,\dots,m, \\ & h_j(\boldsymbol{x}) = 0, \quad j = 1,\dots,p, \end{aligned} \tag{23.2}$$

其中 f, g_i, h_j 都二阶连续可微。

约束怎样近似 Newton 法把目标近似到二阶。约束若也近似到二阶，模型的可行域由二次曲面围成，这样的子问题本身就难解。所以约束只取一阶，用切平面代替曲面。记 $\boldsymbol{d}$ 为待求的步，把约束的值和梯度在 $\boldsymbol{x}^{(t)}$ 处取定，有

$$h_j(\boldsymbol{x}^{(t)}+\boldsymbol{d}) \approx h_j(\boldsymbol{x}^{(t)}) + \langle \nabla h_j(\boldsymbol{x}^{(t)}), \boldsymbol{d}\rangle.$$

把各条约束的梯度按行排成 Jacobian 矩阵，记 $\boldsymbol{A}^{(t)} \in \mathbb{R}^{p\times n}$ 的第 j 行为 $\nabla h_j(\boldsymbol{x}^{(t)})^{\mathsf{T}}$，$\boldsymbol{G}^{(t)} \in \mathbb{R}^{m\times n}$ 的第 i 行为 $\nabla g_i(\boldsymbol{x}^{(t)})^{\mathsf{T}}$。约束的值记作向量 $\boldsymbol{h}^{(t)}$ 和 $\boldsymbol{g}^{(t)}$。这样，要求线性化后的约束成立就是

$$\boldsymbol{h}^{(t)} + \boldsymbol{A}^{(t)}\boldsymbol{d} = \boldsymbol{0}, \qquad \boldsymbol{g}^{(t)} + \boldsymbol{G}^{(t)}\boldsymbol{d} \le \boldsymbol{0}. \tag{23.3}$$

以问题 (23.1)为例，从 $\boldsymbol{x}^{(0)} = (1.5, 0.5)^{\mathsf{T}}$ 出发。约束的值和梯度是

$$h^{(0)} = 2.25 + 0.25 - 2 = 0.5, \qquad \boldsymbol{A}^{(0)} = (3, 1).$$

线性化约束于是成为

$$3d_1 + d_2 + 0.5 = 0.$$

图 23.1(a) 中的虚线就是这条直线。$\boldsymbol{x}^{(0)}$ 在圆外，过它有一条等值线 $h = 0.5$。虚线与这条等值线在 $\boldsymbol{x}^{(0)}$ 处的切线平行，并向圆的方向平移，平移量按一阶估计恰好抵消 $h^{(0)} = 0.5$ 的违约。

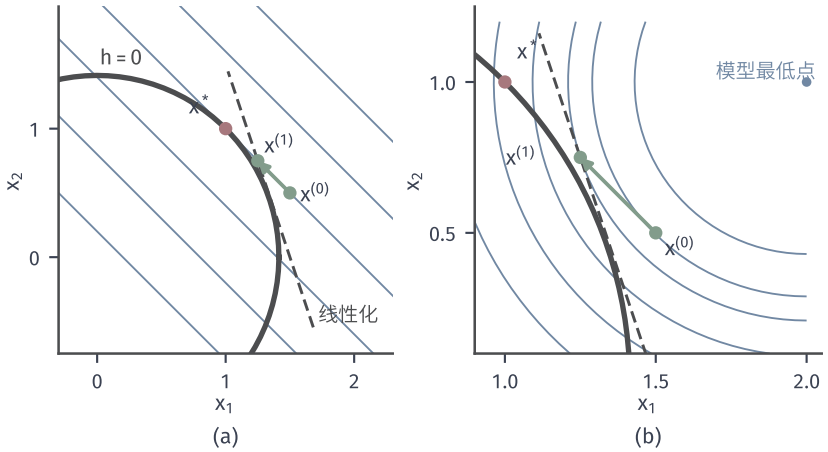


图 23.1 问题 (23.1)的第一个局部模型。深灰粗线是圆 $h = 0$，虚线是线性化约束，绿点是迭代点，红点是解。(a) 蓝色直线是目标的等值线，步落在虚线上而不在圆上。(b) 放大的局部，蓝色圆是取 $\boldsymbol{B}^{(0)} = 2\boldsymbol{I}$ 时模型的等值线，模型无约束的最低点在右上方，受虚线限制后，最优步停在等值线与虚线相切的地方。

目标怎样近似 目标的一阶项仍取 $\langle \nabla f(\boldsymbol{x}^{(t)}), \boldsymbol{d}\rangle$，二次项用一个对称矩阵 $\boldsymbol{B}^{(t)}$。把两部分合起来，就得到局部模型。下面的定义里 $\boldsymbol{B}^{(t)}$ 暂时留作待定，它的选取马上讨论。

定义 23.1　局部二次规划与 SQP　给定当前点 $\boldsymbol{x}^{(t)}$ 与对称矩阵 $\boldsymbol{B}^{(t)}$，**局部二次规划**（local quadratic program）是以 $\boldsymbol{d} \in \mathbb{R}^n$ 为未知量的问题

$$\begin{aligned} \min_{\boldsymbol{d}} \quad & \langle \nabla f(\boldsymbol{x}^{(t)}), \boldsymbol{d}\rangle + \frac{1}{2}\boldsymbol{d}^{\top}\boldsymbol{B}^{(t)}\boldsymbol{d} \\ \text{s.t.} \quad & \boldsymbol{h}^{(t)} + \boldsymbol{A}^{(t)}\boldsymbol{d} = \boldsymbol{0}, \\ & \boldsymbol{g}^{(t)} + \boldsymbol{G}^{(t)}\boldsymbol{d} \le \boldsymbol{0}. \end{aligned} \tag{23.4}$$

反复构造并求解这样的子问题、用其解更新迭代点和乘子的方法，称为**序列二次规划**（sequential quadratic programming，SQP）。

目标是二次的、约束是线性的，这就是第 20章的二次规划（QP）。每一项的职责不同：目标梯度指出一阶意义下该往哪里走；$\boldsymbol{h}^{(t)}, \boldsymbol{g}^{(t)}$ 说明当前违约多少；两个 Jacobian 说明约束怎样随步变化；$\boldsymbol{B}^{(t)}$ 说明走远了之后模型该怎样弯曲。

曲率为什么不能只取目标的 Hessian　最自然的想法是令 $\boldsymbol{B}^{(t)} = \nabla^2 f(\boldsymbol{x}^{(t)})$。式 (23.1)直接否定了这个想法。这里 $\nabla^2 f = \boldsymbol{0}$，模型的目标退化成线性函数，而可行集是一条直线，只要目标沿这条直线的斜率不为零，模型就没有下界。可是真实问题在圆上明明有一个弯曲的碗。

这只碗来自约束的弯曲。设想沿圆周走：坐标 x_1, x_2 本身在转弯，所以线性函数 f 沿圆周读出来的数值是弯的。模型把圆拉直成了直线，这部分弯曲必须另外算回目标的二次项。

下面把这件事算清楚。设 $\boldsymbol{x}(s)$ 是一条留在等式约束上的光滑曲线，它在 $s = 0$ 处经过 $\boldsymbol{x}$，速度是 $\boldsymbol{v}$，加速度是 $\boldsymbol{w}$。对恒等式 $h_j(\boldsymbol{x}(s)) = 0$ 在 $s = 0$ 处求两次导数，得到

$$\langle \nabla h_j(\boldsymbol{x}), \boldsymbol{v}\rangle = 0, \qquad \langle \nabla h_j(\boldsymbol{x}), \boldsymbol{w}\rangle + \boldsymbol{v}^{\top}\nabla^2 h_j(\boldsymbol{x})\boldsymbol{v} = 0.$$

目标沿这条曲线的二阶导数由链式法则给出，它含有加速度 $\boldsymbol{w}$：

$$\frac{\mathrm{d}^2}{\mathrm{d}s^2} f(\boldsymbol{x}(s))\Big|_{s=0} = \boldsymbol{v}^{\top}\nabla^2 f(\boldsymbol{x})\boldsymbol{v} + \langle \nabla f(\boldsymbol{x}), \boldsymbol{w}\rangle.$$

第 17章的一阶条件说，KKT 点上 $\nabla f + \sum_j \nu_j \nabla h_j = \mathbf{0}$，这里记 Lagrange 函数为 $\mathcal{L} = f + \sum_i \lambda_i g_i + \sum_j \nu_j h_j$。把 ∇f 代换掉，再用前面关于 $\boldsymbol{w}$ 的恒等式，得到

$$\langle \nabla f, \boldsymbol{w} \rangle = -\sum_j \nu_j \langle \nabla h_j, \boldsymbol{w} \rangle = \sum_j \nu_j \boldsymbol{v}^{\mathsf{T}} \nabla^2 h_j \boldsymbol{v}.$$

代回上式，加速度消失了，剩下的正是 Lagrange 函数的 Hessian：

$$\left. \frac{\mathrm{d}^2}{\mathrm{d}s^2} f(\boldsymbol{x}(s)) \right|_{s=0} = \boldsymbol{v}^{\mathsf{T}} \nabla^2_{\boldsymbol{xx}} \mathcal{L}(\boldsymbol{x}, \boldsymbol{\nu}) \boldsymbol{v}. \tag{23.5}$$

这里乘子把约束的弯曲折算成了目标的弯曲，它正是第 17章二阶条件里出现 $\nabla^2_{\boldsymbol{xx}}\mathcal{L}$ 的原因。活动的不等式在其边界上同样处理，不活动的不等式乘子为零，不贡献曲率。

在圆上验证一下。沿圆取弧长参数 s，解 $\boldsymbol{x}^\star$ 处的乘子由 $(-1,-1)^{\mathsf{T}} + \nu(2,2)^{\mathsf{T}} = \mathbf{0}$ 得 $\nu^\star = 1/2$，于是

$$\nabla^2_{\boldsymbol{xx}} \mathcal{L} = 2\nu^\star \boldsymbol{I} = \boldsymbol{I}.$$

单位切向量 $\boldsymbol{v}$ 给出 $\boldsymbol{v}^{\mathsf{T}} \boldsymbol{I} \boldsymbol{v} = 1$。另一方面，沿圆有 $f = -2\cos(s/\sqrt{2})$，它在 $s = 0$ 处的二阶导数是

$$\left. \frac{\mathrm{d}^2 f}{\mathrm{d}s^2} \right|_{s=0} = 2 \cdot \frac{1}{2} = 1,$$

两者相等。图 23.2(a) 画的就是这件事：带 Lagrange 曲率的模型与圆上的目标贴合，只用 $\nabla^2 f$ 的模型是一条平线。

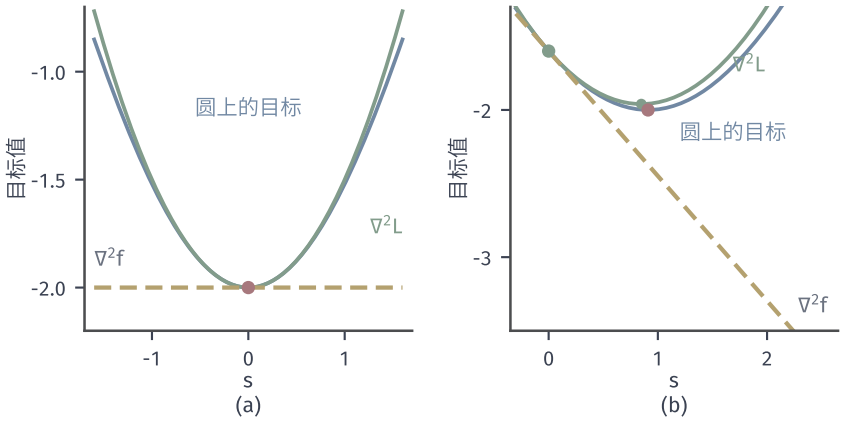


图 23.2　沿约束的目标与两种模型，s 是弧长（对模型是沿切线的距离）。蓝线是圆上真实的目标；绿线的二次项取 $\nabla^2_{\boldsymbol{xx}}\mathcal{L} = \boldsymbol{I}$；黄色虚线的二次项取 $\nabla^2 f = \mathbf{0}$。(a) 在解 $\boldsymbol{x}^\star$ 处（红点）。(b) 在圆上的点 $(1.4, 0.2)^{\mathsf{T}}$ 处（左侧绿点）：绿色模型的最低点靠近真实最低点，只用 $\nabla^2 f$ 的模型沿切线一路下降，没有下界。

式 (23.5)的推导用到了 KKT 点上的梯度关系，所以严格说它是解处的性质。迭代中手里只有估计值，于是取

$$\boldsymbol{B}^{(t)} = \nabla^2_{\boldsymbol{xx}}\mathcal{L}(\boldsymbol{x}^{(t)}, \boldsymbol{\lambda}^{(t)}, \boldsymbol{\nu}^{(t)}) = \nabla^2 f + \sum_{i=1}^{m} \lambda_i^{(t)} \nabla^2 g_i + \sum_{j=1}^{p} \nu_j^{(t)} \nabla^2 h_j, \tag{23.6}$$

右端都在 $\boldsymbol{x}^{(t)}$ 处取值，或取它的近似（第 23.4.2节）。这解释了 SQP 为什么要同时维护原始变量和乘子：没有乘子，就写不出模型的曲率。

图 23.2(b) 显示了乘子估计不太准时的情形。点 $(1.4, 0.2)^{\mathsf{T}}$ 在圆上但不是解，取 $\nu = 1/2$，绿色模型的最低点仍然靠近真实的最低点。类比“局部模型信多远”：线性化约束告诉我们该待在哪里，乘子曲率告诉我们沿着允许的方向能走多远。这个类比在远离解时失效，那时乘子可能是错的，模型未必是碗，这是第 23.4节的话题。

子问题的乘子　QP 也有自己的乘子。记不等式的乘子为 $\hat{\boldsymbol{\lambda}}$，等式的乘子为 $\hat{\boldsymbol{\nu}}$。线性约束本身满足约束资格，所以把第 17章的 KKT 条件用于式 (23.4)时，它的每个局部解都满足

$$\begin{aligned} \boldsymbol{B}^{(t)}\boldsymbol{d} + \nabla f(\boldsymbol{x}^{(t)}) + (\boldsymbol{A}^{(t)})^{\mathsf{T}}\hat{\boldsymbol{\nu}} + (\boldsymbol{G}^{(t)})^{\mathsf{T}}\hat{\boldsymbol{\lambda}} &= \boldsymbol{0}, \\ \boldsymbol{h}^{(t)} + \boldsymbol{A}^{(t)}\boldsymbol{d} = \boldsymbol{0}, \qquad \boldsymbol{g}^{(t)} + \boldsymbol{G}^{(t)}\boldsymbol{d} &\le \boldsymbol{0}, \\ \hat{\boldsymbol{\lambda}} \ge \boldsymbol{0}, \qquad \hat{\lambda}_i\big(g_i^{(t)} + \langle \nabla g_i^{(t)}, \boldsymbol{d}\rangle\big) &= 0, \quad i = 1, \dots, m. \end{aligned} \tag{23.7}$$

把 $\boldsymbol{d} = \boldsymbol{0}$ 代入式 (23.7)，第一行成为原问题的 Lagrange 驻定条件，第二行成为原问题的可行性，第三行成为原问题的乘子非负与互补。这就是下面的引理，它说明模型和原问题在解处是一致的。

引理 23.2　零步与 KKT 点　$\boldsymbol{d} = \boldsymbol{0}$ 连同乘子 $(\hat{\boldsymbol{\lambda}}, \hat{\boldsymbol{\nu}})$ 满足式 (23.7)，当且仅当 $(\boldsymbol{x}^{(t)}, \hat{\boldsymbol{\lambda}}, \hat{\boldsymbol{\nu}})$ 满足原问题 (23.2)的 KKT 条件。

证明　令 $\boldsymbol{d} = \boldsymbol{0}$，含 $\boldsymbol{B}^{(t)}$ 的项消失，线性化项都等于在 $\boldsymbol{x}^{(t)}$ 处的取值。式 (23.7)逐行就是原问题在 $\boldsymbol{x}^{(t)}$ 处的驻定、可行、乘子非负和互补条件，反过来也一样。 ■

引理与 $\boldsymbol{B}^{(t)}$ 无关，所以不论曲率怎样近似，模型的不动点都是原问题的 KKT 点。曲率只影响走向这个点的速度。解完 QP 后，新的乘子估计可以直接取子问题的乘子，当步长 $\alpha^{(t)} \in (0, 1]$ 时按比例插值：

$$\begin{aligned} \boldsymbol{\lambda}^{(t+1)} &= \boldsymbol{\lambda}^{(t)} + \alpha^{(t)}\big(\hat{\boldsymbol{\lambda}} - \boldsymbol{\lambda}^{(t)}\big), \\ \boldsymbol{\nu}^{(t+1)} &= \boldsymbol{\nu}^{(t)} + \alpha^{(t)}\big(\hat{\boldsymbol{\nu}} - \boldsymbol{\nu}^{(t)}\big). \end{aligned} \tag{23.8}$$

23.1 局部二次模型
23.2 等式 QP 的求解
23.3 有效集法（Active-Set）
23.4 曲率的处理
23.5 更新的接受
23.6 模型的修复
23.7 收敛与计算成本
23.8 本章小结

一轮计算的结构 图 23.3把一轮计算的部件排在一起。求值之后得到子问题，子问题给出步和乘子，步还要放回原问题检验。两处可能出岔：子问题可能无解，步也可能被拒绝。后面各节依次处理这些部件。

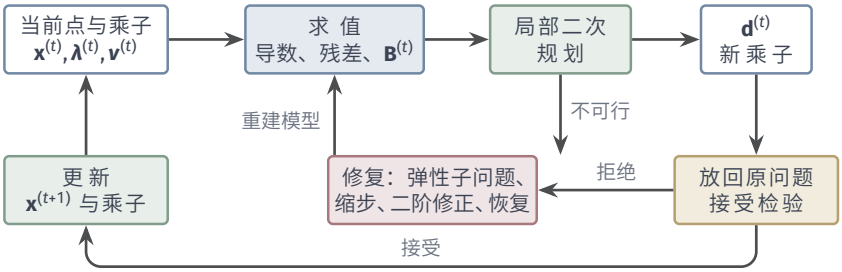


图 23.3 SQP 一轮计算的结构。绿框是模型的构造与接受后的更新，黄框是把步放回非线性问题的检验，红框是子问题无解或候选步被拒绝时的修复。修复之后重新建模或重新求解。

需要说明的是，SQP 规定的是“解一列局部 QP”，并没有规定用什么方法解 QP。下面用有效集法讲解，因为它的逻辑最贴近“哪些约束算数”这个问题；QP 也可以用内点法或其他方法求解，第 24章的内点法思想同样适用于 QP。

局部模型还有一点要记住：模型可行不等于原问题可行。式 (23.3)只是切平面，步 $\boldsymbol{d}$ 落在切平面上，一般不在原来的曲面上。这个缺口贯穿全章，第 23.5节和第 23.6节专门处理它。

23.2 等式 QP 的求解

式 (23.4)只含等式时，怎样求出它的解，这个解又在什么条件下才算数？这是 SQP 最基本的一步，下一节处理不等式时，每一轮要解的也是这种问题。为减少上标，本节在不引起混淆时省去 (t)，并记 $\boldsymbol{g}=\nabla f(\boldsymbol{x}^{(t)})$。

KKT 线性系统 只含等式时，条件 (23.7)的第一、二行就是全部要求。它们对 $(\boldsymbol{d},\hat{\boldsymbol{\nu}})$ 是线性的，合起来写成块方程

$$\underbrace{\begin{bmatrix}\boldsymbol{B} & \boldsymbol{A}^{\top}\\ \boldsymbol{A} & \mathbf{0}\end{bmatrix}}_{\boldsymbol{K}}\begin{bmatrix}\boldsymbol{d}\\ \hat{\boldsymbol{\nu}}\end{bmatrix}=-\begin{bmatrix}\boldsymbol{g}\\ \boldsymbol{h}\end{bmatrix}. \tag{23.9}$$

矩阵 $\boldsymbol{K}\in\mathbb{R}^{(n+p)\times(n+p)}$ 称为**KKT 矩阵**（KKT matrix）。它对称但不定，零对角块使它不可能正定，所以不能用 Cholesky 分解。

这个方程有解并不等于模型有最小点。要回答后一个问题，得看 $\boldsymbol{B}$ 在允许的方向上是否向上弯。允许的方向是满足 $\boldsymbol{A}\boldsymbol{v}=\mathbf{0}$ 的方向，它们构成 $\boldsymbol{A}$

的零空间。取矩阵 $\boldsymbol{Z} \in \mathbb{R}^{n \times (n-p)}$，其各列构成这个零空间的一组基，就把问题缩到这 $n-p$ 维上。矩阵 $\boldsymbol{Z}^{\top}\boldsymbol{B}\boldsymbol{Z}$ 称为**约化 Hessian**（reduced Hessian）。

定理 23.3　等式 QP 的可解性　设 $\boldsymbol{A} \in \mathbb{R}^{p \times n}$ 行满秩，$\boldsymbol{Z}$ 的各列是其零空间的一组基，且 $\boldsymbol{Z}^{\top}\boldsymbol{B}\boldsymbol{Z} \succ \boldsymbol{0}$。则 $\boldsymbol{K}$ 可逆，方程 (23.9)有唯一解 $(\boldsymbol{d}, \hat{\boldsymbol{\nu}})$，并且 $\boldsymbol{d}$ 是等式 QP 唯一的全局最小点。

证明　先证 $\boldsymbol{K}$ 可逆。设 $\boldsymbol{K}(\boldsymbol{u}^{\top}, \boldsymbol{w}^{\top})^{\top} = \boldsymbol{0}$，即 $\boldsymbol{B}\boldsymbol{u} + \boldsymbol{A}^{\top}\boldsymbol{w} = \boldsymbol{0}$ 且 $\boldsymbol{A}\boldsymbol{u} = \boldsymbol{0}$。

用 $\boldsymbol{u}^{\top}$ 左乘第一式，并用 $\boldsymbol{A}\boldsymbol{u} = \boldsymbol{0}$ 消去含 $\boldsymbol{w}$ 的项，得到

$$\boldsymbol{u}^{\top}\boldsymbol{B}\boldsymbol{u} = 0.$$

由 $\boldsymbol{A}\boldsymbol{u} = \boldsymbol{0}$ 可写 $\boldsymbol{u} = \boldsymbol{Z}\boldsymbol{z}$，代入上式得到

$$\boldsymbol{z}^{\top}\boldsymbol{Z}^{\top}\boldsymbol{B}\boldsymbol{Z}\boldsymbol{z} = 0.$$

约化 Hessian 正定，所以 $\boldsymbol{z}$ 和 $\boldsymbol{u}$ 都是零向量。第一式于是成为 $\boldsymbol{A}^{\top}\boldsymbol{w} = \boldsymbol{0}$，$\boldsymbol{A}$ 行满秩给出 $\boldsymbol{w} = \boldsymbol{0}$。

再证最小性。设 $\bar{\boldsymbol{d}}$ 是任一可行步，令 $\boldsymbol{v} = \bar{\boldsymbol{d}} - \boldsymbol{d}$，则 $\boldsymbol{A}\boldsymbol{v} = \boldsymbol{0}$。记目标为 q，展开得

$$q(\bar{\boldsymbol{d}}) - q(\boldsymbol{d}) = \langle \boldsymbol{g} + \boldsymbol{B}\boldsymbol{d}, \boldsymbol{v} \rangle + \frac{1}{2}\boldsymbol{v}^{\top}\boldsymbol{B}\boldsymbol{v}.$$

由方程第一行，$\boldsymbol{g} + \boldsymbol{B}\boldsymbol{d} = -\boldsymbol{A}^{\top}\hat{\boldsymbol{\nu}}$，它与 $\boldsymbol{v}$ 正交，第一项为零。所以

$$q(\bar{\boldsymbol{d}}) - q(\boldsymbol{d}) = \frac{1}{2}\boldsymbol{v}^{\top}\boldsymbol{B}\boldsymbol{v}.$$

$\boldsymbol{v} \neq \boldsymbol{0}$ 时 $\boldsymbol{v} = \boldsymbol{Z}\boldsymbol{z}$ 且 $\boldsymbol{z} \neq \boldsymbol{0}$，右端为正。 ■

两个条件各有分工。行满秩保证约束不互相矛盾、乘子唯一：若 $\boldsymbol{A}$ 有一行是另一行的倍数而右端不相称，线性化约束根本无解，这种情形留到第 23.6.1节。约化 Hessian 正定保证驻点是最小点，它只要求 $\boldsymbol{B}$ 在 $n-p$ 个允许的方向上正定，不要求 $\boldsymbol{B}$ 在全空间正定，第 23.4节会看到两者的差别。

直接解鞍点方程　第一种做法是把 $\boldsymbol{K}$ 当作一个 $(n+p)$ 阶的对称不定矩阵，做带主元的 $\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\top}$ 分解后回代。它一次同时给出 $\boldsymbol{d}$ 和 $\hat{\boldsymbol{\nu}}$，也能保持稀疏性，是大规模稀疏问题的常用选择。

小问题可以手算，办法是先消去 $\boldsymbol{d}$。回到第一个模型，取 $\boldsymbol{\nu}^{(0)}=1$，于是 $\boldsymbol{B}=2\nu^{(0)}\boldsymbol{I}=2\boldsymbol{I}$，数据是

$$\boldsymbol{g}=(-1,-1)^{\top},\qquad h=0.5,\qquad \boldsymbol{A}=(3,1).$$

方程 (23.9)的第一行给出 $\boldsymbol{d}$ 关于 $\hat{\nu}$ 的表达式：

$$\boldsymbol{d}=-\frac{1}{2}\bigl(\boldsymbol{g}+\hat{\nu}\boldsymbol{A}^{\top}\bigr)=\frac{1}{2}\begin{bmatrix}1-3\hat{\nu}\\ 1-\hat{\nu}\end{bmatrix}.$$

代入第二行 $\boldsymbol{A}\boldsymbol{d}=-h$，左端是 $\frac{1}{2}(3-9\hat{\nu}+1-\hat{\nu})=2-5\hat{\nu}$，于是

$$2-5\hat{\nu}=-0.5,\qquad \text{即}\qquad \hat{\nu}=0.5.$$

再代回 $\boldsymbol{d}$ 的表达式，得到

$$\boldsymbol{d}=(-0.25,\ 0.25)^{\top}.$$

这就是图 23.1中的绿色箭头。

在零空间中求解　第二种做法把步分成两段，分别完成两件事。第一段让线性化约束成立，第二段在不破坏它的前提下降低模型。取 $\boldsymbol{Y}\in\mathbb{R}^{n\times p}$ 使 $\boldsymbol{A}\boldsymbol{Y}$ 可逆，把步写成

$$\boldsymbol{d}=\boldsymbol{Y}\boldsymbol{d}_{Y}+\boldsymbol{Z}\boldsymbol{d}_{Z}. \tag{23.10}$$

因为 $\boldsymbol{A}\boldsymbol{Z}=\boldsymbol{0}$，约束 $\boldsymbol{A}\boldsymbol{d}=-\boldsymbol{h}$ 只约束 $\boldsymbol{d}_{Y}$，得到 p 维的方程

$$\boldsymbol{A}\boldsymbol{Y}\boldsymbol{d}_{Y}=-\boldsymbol{h}. \tag{23.11}$$

固定 $\boldsymbol{d}_{Y}$，把式 (23.10)代入目标，对 $\boldsymbol{d}_{Z}$ 求最小，就是 $n-p$ 维的无约束二次问题，其驻点方程为

$$\boldsymbol{Z}^{\top}\boldsymbol{B}\boldsymbol{Z}\,\boldsymbol{d}_{Z}=-\boldsymbol{Z}^{\top}\bigl(\boldsymbol{g}+\boldsymbol{B}\boldsymbol{Y}\boldsymbol{d}_{Y}\bigr). \tag{23.12}$$

最后，方程 (23.9)的第一行左乘 $\boldsymbol{Y}^{\top}$，就解出乘子：

$$(\boldsymbol{A}\boldsymbol{Y})^{\top}\hat{\boldsymbol{\nu}}=-\boldsymbol{Y}^{\top}\bigl(\boldsymbol{g}+\boldsymbol{B}\boldsymbol{d}\bigr). \tag{23.13}$$

继续用同一组数据。取 $\boldsymbol{Y}=\boldsymbol{A}^{\top}=(3,1)^{\top}$，此时 $\boldsymbol{A}\boldsymbol{Y}=10$，再取 $\boldsymbol{Z}=(1,-3)^{\top}$，可以核对 $\boldsymbol{A}\boldsymbol{Z}=0$。由式 (23.11)，

$$d_{Y}=-\frac{0.5}{10}=-0.05,\qquad \boldsymbol{Y}d_{Y}=(-0.15,\ -0.05)^{\top}.$$

计算式 (23.12)的两边。约化 Hessian 是 $\boldsymbol{Z}^{\top}\boldsymbol{B}\boldsymbol{Z} = 2 \times 10 = 20$，右端需要的向量和内积是

$$\boldsymbol{g} + \boldsymbol{B}\boldsymbol{Y} d_Y = (-1.3,\ -1.1)^{\top}, \qquad \boldsymbol{Z}^{\top}(\boldsymbol{g} + \boldsymbol{B}\boldsymbol{Y} d_Y) = -1.3 + 3.3 = 2.$$

于是

$$d_Z = -\frac{2}{20} = -0.1, \qquad \boldsymbol{Z} d_Z = (-0.1,\ 0.3)^{\top}.$$

两段相加，得到 $\boldsymbol{d} = (-0.25, 0.25)^{\top}$，和直接解法一致。用式 (23.13)求乘子，先算 $\boldsymbol{g} + \boldsymbol{B}\boldsymbol{d} = (-1.5, -0.5)^{\top}$，于是

$$10\,\hat{\nu} = -(3, 1)\begin{bmatrix} -1.5 \\ -0.5 \end{bmatrix} = 5, \qquad \hat{\nu} = 0.5.$$

图 23.4是这两段的几何。紫色的一段垂直于虚线，它只管把点送到线性化约束上；黄色的一段沿虚线走，它只管沿允许的方向降低模型，这里的 $\boldsymbol{Z}$ 就是把“沿虚线走多少”变成 $\mathbb{R}^2$ 中位移的那个矩阵。

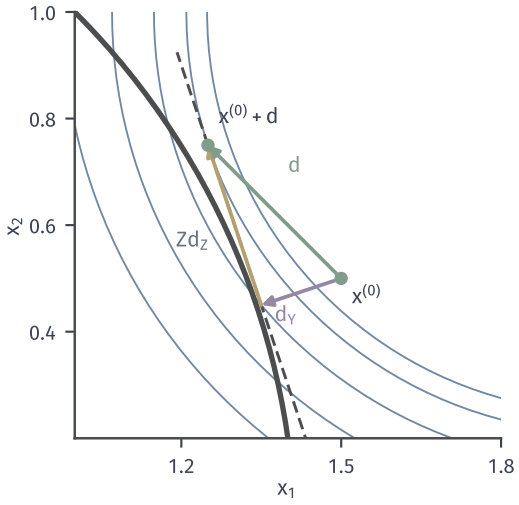


图 23.4 第一个局部模型的两段分解。深灰粗线是圆，虚线是线性化约束，蓝线是模型的等值线。紫色 $\boldsymbol{Y} d_Y$ 从 $\boldsymbol{x}^{(0)}$ 走到虚线，黄色 $\boldsymbol{Z} d_Z$ 沿虚线走到模型的条件最小点，两段之和是绿色的 $\boldsymbol{d}$。

比较项	解 KKT 系统	零空间方法
分解对象	$(n+p)$ 阶对称不定	$\boldsymbol{A}$ 的分解与 $n-p$ 阶约化矩阵
$n-p$ 很小时	仍解 $n+p$ 阶	约化矩阵很小，便宜
稀疏性	容易保持	$\boldsymbol{Z}$ 可能变稠密
检查曲率	需看分解的惯性	直接检查约化矩阵

表 23.1 等式 QP 两种解法的比较。

与原问题 Newton 步的关系　到这里，KKT 系统还只是模型的条件。现在换一个角度，从原问题出发。只含等式时，原问题的 KKT 条件是非线性方程组

$$\boldsymbol{F}(\boldsymbol{x},\boldsymbol{\nu})=\begin{bmatrix}\nabla f(\boldsymbol{x})+\boldsymbol{A}(\boldsymbol{x})^{\top}\boldsymbol{\nu}\\ \boldsymbol{h}(\boldsymbol{x})\end{bmatrix}=\boldsymbol{0}. \tag{23.14}$$

自然的想法是对这个方程组直接用 Newton 法。下面的定理说，这和解局部 QP 是同一件事。

定理 23.4　SQP 与 KKT 方程的 Newton 法　设 $\boldsymbol{B}$ 取 Lagrange 函数在 $(\boldsymbol{x},\boldsymbol{\nu})$ 处对 $\boldsymbol{x}$ 的 Hessian。则 $(\boldsymbol{\delta}_x,\boldsymbol{\delta}_\nu)$ 是 $\boldsymbol{F}$ 在 $(\boldsymbol{x},\boldsymbol{\nu})$ 处的 Newton 步，当且仅当 $\boldsymbol{d}=\boldsymbol{\delta}_x$，$\hat{\boldsymbol{\nu}}=\boldsymbol{\nu}+\boldsymbol{\delta}_\nu$ 满足方程 (23.9)。

证明　$\boldsymbol{F}$ 的第一块对 $\boldsymbol{x}$ 的导数是 $\nabla^2_{\boldsymbol{xx}}\mathcal{L}=\boldsymbol{B}$，对 $\boldsymbol{\nu}$ 的导数是 $\boldsymbol{A}^{\top}$；第二块对 $\boldsymbol{x}$ 的导数是 $\boldsymbol{A}$，对 $\boldsymbol{\nu}$ 的导数为零。所以 Newton 方程是

$$\begin{bmatrix}\boldsymbol{B} & \boldsymbol{A}^{\top}\\ \boldsymbol{A} & \boldsymbol{0}\end{bmatrix}\begin{bmatrix}\boldsymbol{\delta}_x\\ \boldsymbol{\delta}_\nu\end{bmatrix}=-\begin{bmatrix}\boldsymbol{g}+\boldsymbol{A}^{\top}\boldsymbol{\nu}\\ \boldsymbol{h}\end{bmatrix}.$$

第一行把右端的 $-\boldsymbol{A}^{\top}\boldsymbol{\nu}$ 移到左边，与 $\boldsymbol{A}^{\top}\boldsymbol{\delta}_\nu$ 合并成 $\boldsymbol{A}^{\top}(\boldsymbol{\nu}+\boldsymbol{\delta}_\nu)$，就得到方程 (23.9)。每一步都可逆，反过来也成立。 ■

定理给出了两种读法。模型的读法是“在切平面上最小化一个二次函数”，Newton 的读法是“解 KKT 这组方程”。前者告诉我们什么时候解是最小点，后者告诉我们为什么收敛快。两种读法也有差别：Newton 法只求方程的根，不区分极小点和极大点；模型的读法多出了约化曲率这一判据。

计算过程　下面把等式约束的 SQP 用问题 (23.1)完整走几轮。这里用精确的 Lagrange Hessian 和全步长，$\alpha^{(t)}=1$，步的接受规则留到第 23.5节。

变量

- $\boldsymbol{x}^{(t)}\in\mathbb{R}^n$：当前点，例中 $n=2$。
- $\boldsymbol{\nu}^{(t)}\in\mathbb{R}^p$：当前乘子估计，例中 $p=1$。
- $\boldsymbol{g}^{(t)}\in\mathbb{R}^n$、$\boldsymbol{h}^{(t)}\in\mathbb{R}^p$：目标梯度与约束值。
- $\boldsymbol{A}^{(t)}\in\mathbb{R}^{p\times n}$：约束 Jacobian，例中是 1×2 的行向量。
- $\boldsymbol{B}^{(t)}\in\mathbb{R}^{n\times n}$：Lagrange Hessian，例中为 $2\nu^{(t)}\boldsymbol{I}$。
- $\boldsymbol{d}^{(t)}\in\mathbb{R}^n$、$\hat{\boldsymbol{\nu}}\in\mathbb{R}^p$：子问题的解与乘子。

初始化 给定 $\boldsymbol{x}^{(0)}$ 和 $\boldsymbol{\nu}^{(0)}$，以及精度 $\varepsilon > 0$。例中

$$\boldsymbol{x}^{(0)} = (1.5,\ 0.5)^{\top}, \qquad \nu^{(0)} = 1, \qquad \varepsilon = 10^{-10}.$$

每轮更新

1. 在 $\boldsymbol{x}^{(t)}$ 处计算 $\boldsymbol{g}^{(t)}, \boldsymbol{h}^{(t)}, \boldsymbol{A}^{(t)}$，并由式 (23.6)计算 $\boldsymbol{B}^{(t)}$。

   例中第一轮的数值已算过。第二轮 $\boldsymbol{x}^{(1)} = (1.25, 0.75)^{\top}$，$\nu^{(1)} = 0.5$，数据是

   $$\boldsymbol{g}^{(1)} = (-1, -1)^{\top}, \quad h^{(1)} = 0.125, \quad \boldsymbol{A}^{(1)} = (2.5, 1.5), \quad \boldsymbol{B}^{(1)} = \boldsymbol{I}.$$

2. 解方程 (23.9)得 $\boldsymbol{d}^{(t)}$ 和 $\hat{\nu}$。$\boldsymbol{K}$ 可逆时，它们的显式形式是

   $$\begin{bmatrix} \boldsymbol{d}^{(t)} \\ \hat{\nu} \end{bmatrix} = -\left(\boldsymbol{K}^{(t)}\right)^{-1} \begin{bmatrix} \boldsymbol{g}^{(t)} \\ \boldsymbol{h}^{(t)} \end{bmatrix}. \tag{23.15}$$

   例中第一轮得 $\boldsymbol{d}^{(0)} = (-0.25, 0.25)^{\top}$，$\hat{\nu} = 0.5$。第二轮由第一行 $\boldsymbol{d} = \boldsymbol{e} - \hat{\nu}\boldsymbol{A}^{\top}$，其中 $\boldsymbol{e} = (1, 1)^{\top}$，代入第二行得

   $$4 - 8.5\,\hat{\nu} = -0.125, \qquad \hat{\nu} = \frac{33}{68} \approx 0.48529.$$

   代回第一行，得到

   $$\boldsymbol{d}^{(1)} \approx (-0.21324,\ 0.27206)^{\top}.$$

3. 更新迭代点和乘子：

   $$\boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} + \boldsymbol{d}^{(t)}, \qquad \boldsymbol{\nu}^{(t+1)} = \hat{\boldsymbol{\nu}}. \tag{23.16}$$

   例中前两轮得到

   $$\boldsymbol{x}^{(1)} = (1.25,\ 0.75)^{\top}, \qquad \boldsymbol{x}^{(2)} \approx (1.03676,\ 1.02206)^{\top}.$$

   第三轮的数据是 $h^{(2)} \approx 0.11949$，$\boldsymbol{A}^{(2)} \approx (2.07353, 2.04412)$，$\boldsymbol{B}^{(2)} \approx 0.97059\,\boldsymbol{I}$，同样解方程得

   $$\hat{\nu} \approx 0.49937, \qquad \boldsymbol{d}^{(2)} \approx (-0.03653,\ -0.02140)^{\top}.$$

4. 若下面两个残差都不超过 ε，就停止，否则回到第 1 步：

   $$\|\boldsymbol{g}^{(t)} + (\boldsymbol{A}^{(t)})^{\top}\boldsymbol{\nu}^{(t)}\|_2, \qquad \|\boldsymbol{h}^{(t)}\|_2.$$

23.1 局部二次模型
23.2 等式 QP 的求解
23.3 有效集法（Active-Set）
23.3.1 工作集的更新
23.3.2 有效集法与 SQP
23.4 曲率的处理
23.5 更新的接受
23.6 模型的修复
23.7 收敛与计算成本
23.8 本章小结

例中在 $t=5$ 时停止。

最终得到 $\boldsymbol{x}^{(5)} \approx (1,1)^{\mathsf{T}}$，$\nu^{(5)} \approx 0.5$。表 23.2列出各轮结果，图 23.5画出路径与残差。

t	$x_1^{(t)}$	$x_2^{(t)}$	$\nu^{(t)}$	$\lvert h^{(t)}\rvert$	$\lVert \boldsymbol{x}^{(t)}-\boldsymbol{x}^{\star}\rVert_2$
0	1.5	0.5	1	0.5	7.07×10^{-1}
1	1.25	0.75	0.5	0.125	3.54×10^{-1}
2	1.03676	1.02206	0.48529	0.11949	4.29×10^{-2}
3	1.00024	1.00066	0.49937	1.79×10^{-3}	7.02×10^{-4}
4	1.00000	1.00000	0.50000	4.9×10^{-7}	4.19×10^{-7}
5	1.00000	1.00000	0.50000	$<10^{-12}$	2.69×10^{-13}

表 23.2 问题 (23.1)上全步长 SQP 的各轮结果。

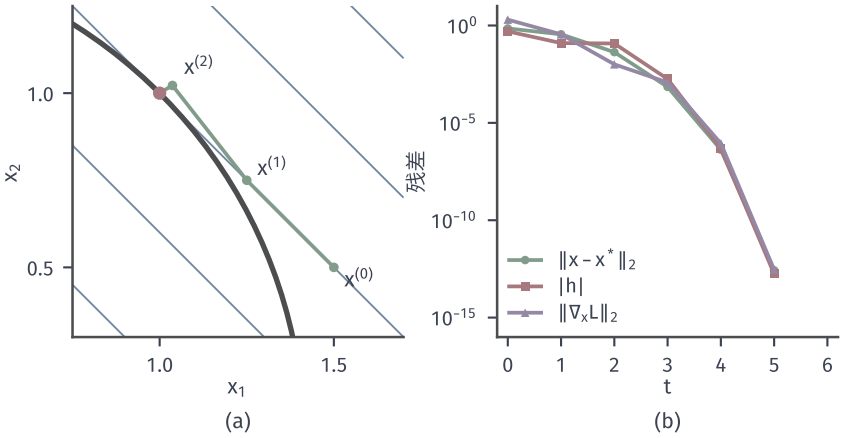


图 23.5 问题 (23.1)上全步长 SQP 的运行结果。(a) 路径（绿），中间各点都不在圆上。(b) 到解的距离、约束残差和 Lagrange 梯度随迭代的变化，纵轴为对数，后几轮每步的有效数字大致翻倍。

表中有两点值得注意。第一，约束残差的下降并不均匀，$t=1$ 到 $t=2$ 几乎没有变化，因为这一步走得长，二阶误差 $\|\boldsymbol{d}\|_2^2$ 把线性化的好处抵消了。第二，从 $t=2$ 起误差大致平方下降，这是 Newton 型方法的标志，第 23.7节给出证明。

23.3 有效集法（Active-Set）

等式 QP 一步就能解完。不等式的困难在于事先不知道解处哪些不等式取等号：如果知道，把它们当等式，其余的扔掉，就回到了上一节。接下来要弄清：怎样一边迭代、一边找出这些约束？

这就像按预算线分配资源。有些预算在最优方案中被用尽，是真正起作用的边界；有些还有富余，暂时可以当它不存在。麻烦在于，只有解出方案后才知道哪些用尽了。有效集法的做法是先猜一组，解一下，看哪里不对，再改这一组。这个类比的边界是，算法改的是它自己维护的集合，这个集合不必与当前点真实触碰的边界完全相同。

要解的 QP 本节讨论一个独立的 QP，记号与局部模型无关，变量写作 $\boldsymbol{x}$：

$$\min_{\boldsymbol{x}\in\mathbb{R}^n}\; q(\boldsymbol{x})=\frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{B}\boldsymbol{x}+\langle \boldsymbol{c},\boldsymbol{x}\rangle \quad \text{s.t.} \quad \langle \boldsymbol{a}_i,\boldsymbol{x}\rangle \le b_i,\quad i=1,\dots,m. \tag{23.17}$$

等式约束若有，始终留在下面要定义的集合里，写法上不必单列。全节的例子是平面上到点 $\boldsymbol{c}^{\circ}=(4,2)^{\top}$ 的投影：

$$q(\boldsymbol{x})=\frac{1}{2}\|\boldsymbol{x}-\boldsymbol{c}^{\circ}\|_2^2,$$

$$g_1:\; x_1+x_2\le 3,\quad g_2:\; -x_1\le 0,\quad g_3:\; -x_2\le 0,\quad g_4:\; x_1+2x_2\le 4. \tag{23.18}$$

它的 $\boldsymbol{B}=\boldsymbol{I}$，$\boldsymbol{c}=-\boldsymbol{c}^{\circ}$，可行域是顶点为 $(0,0),(3,0),(2,1),(0,2)$ 的四边形。

活动约束与工作集 先把两个容易混淆的集合分开。在可行点 $\boldsymbol{x}$ 处，取等号的约束构成**活动集**（active set），它由 $\boldsymbol{x}$ 决定。算法还维护一个下标集合 $\boldsymbol{W}$，这一轮把其中的约束当等式处理，它称为**工作集**（working set），由算法的历史决定。

可行点上工作集总是活动集的子集，但两者不必相等。图 23.6给出三种情形：(a) 点贴着 g_3 的边，g_3 活动，算法却可能没把它放进工作集；(b) 在顶点 $(3,0)$ 处两条约束都活动，工作集可以只含其中一条；(c) 两者重合。到了解处，算法想要的是工作集恰好为那些乘子为正的约束。

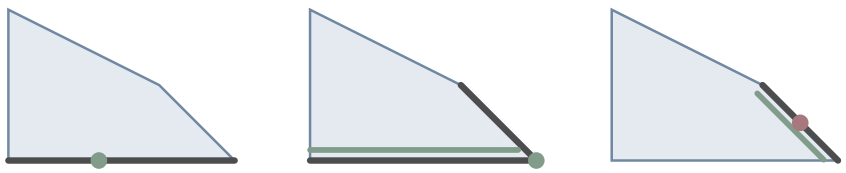


图 23.6 活动集与工作集的区别，可行域取例 (23.18)的四边形。深灰粗线是当前点真实触碰的边，绿色细带标出算法放进工作集的约束，圆点是当前点（红点为解）。

23.1 局部二次模型
23.2 等式 QP 的求解
23.3 有效集法（Active-Set）
23.3.1 工作集的更新
23.3.2 有效集法与 SQP
23.4 曲率的处理
23.5 更新的接受
23.6 模型的修复
23.7 收敛与计算成本
23.8 本章小结

23.3.1 工作集的更新

本小节假设 $\boldsymbol{B} \succ \mathbf{0}$，并且工作集中的约束梯度始终线性无关，已有一个可行的初始点。这样的初始点可以用第 3章两阶段法那样的辅助问题找到。

主要思想　设 $\boldsymbol{x}^{(t)}$ 可行，工作集为 $\boldsymbol{W}$。把 $\boldsymbol{W}$ 中的约束当等式，其余的先不管，问“从这里出发沿这张面能走到哪里”。写成对步 $\boldsymbol{d}$ 的等式 QP，并利用 $\nabla q(\boldsymbol{x}^{(t)}) = \boldsymbol{B}\boldsymbol{x}^{(t)} + \boldsymbol{c}$：

$$\min_{\boldsymbol{d}} \ \frac{1}{2}\boldsymbol{d}^{\top}\boldsymbol{B}\boldsymbol{d} + \langle \nabla q(\boldsymbol{x}^{(t)}), \boldsymbol{d}\rangle \quad \text{s.t.} \quad \langle \boldsymbol{a}_i, \boldsymbol{d}\rangle = 0, \quad i \in \boldsymbol{W}. \tag{23.19}$$

约束里右端是 0，因为 $\boldsymbol{W}$ 中的约束已经取等号，步不能破坏它们。结果分两种情况。

第一种，$\boldsymbol{d} \neq \mathbf{0}$。沿 $\boldsymbol{d}$ 能降低 q，但工作集以外的约束可能挡路。$\boldsymbol{W}$ 以外的约束 i 只在 $\langle \boldsymbol{a}_i, \boldsymbol{d}\rangle > 0$ 时才会变紧，走到边界所允许的比例是 $(b_i - \langle \boldsymbol{a}_i, \boldsymbol{x}^{(t)}\rangle)/\langle \boldsymbol{a}_i, \boldsymbol{d}\rangle$。取其中最小的一个，并且不超过 1，得到**比值检验**（ratio test）：

$$\alpha^{(t)} = \min\Big\{1, \ \min_{i \notin \boldsymbol{W}, \langle \boldsymbol{a}_i, \boldsymbol{d}\rangle > 0} \frac{b_i - \langle \boldsymbol{a}_i, \boldsymbol{x}^{(t)}\rangle}{\langle \boldsymbol{a}_i, \boldsymbol{d}\rangle}\Big\}. \tag{23.20}$$

新点是 $\boldsymbol{x}^{(t)}$ 加上 $\alpha^{(t)}\boldsymbol{d}$。若 $\alpha^{(t)} < 1$，取到最小值的约束称为**阻挡约束**（blocking constraint），把它加入工作集。它满足 $\langle \boldsymbol{a}_b, \boldsymbol{d}\rangle > 0$，而 $\boldsymbol{W}$ 中的约束都有 $\langle \boldsymbol{a}_i, \boldsymbol{d}\rangle = 0$，所以它不在 $\boldsymbol{W}$ 的约束梯度张成的子空间内，加入后仍线性无关。

第二种，$\boldsymbol{d} = \mathbf{0}$。当前点已是这张面上的最小点，该看乘子了。方程 (23.9)的第一行此时给出

$$\boldsymbol{B}\boldsymbol{x}^{(t)} + \boldsymbol{c} + \sum_{i \in \boldsymbol{W}} \lambda_i \boldsymbol{a}_i = \mathbf{0}. \tag{23.21}$$

若所有 $\lambda_i \geq 0$，再令 $\boldsymbol{W}$ 以外的乘子为零，KKT 条件全部成立，$\boldsymbol{B} \succ \mathbf{0}$ 时这就是全局最优解。

若有某个 $\lambda_k < 0$，负乘子说明这条约束不该被按住：它的影子价格是负的，相当于“放松这条预算，成本反而升高”，反过来说，向可行域内部离开这条边能让目标下降。下面的引理把这句话说准。

引理 23.5　释放负乘子约束　设 $\boldsymbol{d} = \mathbf{0}$ 时的乘子满足 $\lambda_k < 0$，令 $\boldsymbol{W}' = \boldsymbol{W} \setminus \{k\}$，并设 $\boldsymbol{d}'$ 是把 $\boldsymbol{W}$ 换成 $\boldsymbol{W}'$ 后问题 (23.19)的解。则 $\boldsymbol{d}' \neq \mathbf{0}$，$\boldsymbol{d}'$ 严格降低 q 的模型，并且

$$\langle \boldsymbol{a}_k, \boldsymbol{d}'\rangle < 0. \tag{23.22}$$

证明 先证 $\boldsymbol{d}' \neq \mathbf{0}$。若 $\boldsymbol{d}' = \mathbf{0}$，则存在系数 μ_i 使 $\nabla q + \sum_{i \in \boldsymbol{W}'} \mu_i \boldsymbol{a}_i = \mathbf{0}$。把它与式 (23.21)相减，得到 $\boldsymbol{W}$ 中约束梯度的一个线性关系，其中 $\boldsymbol{a}_k$ 的系数是 $\lambda_k \neq 0$，与线性无关矛盾。

再看方向。$\boldsymbol{d}'$ 的驻定条件是

$$\boldsymbol{B}\boldsymbol{d}' + \nabla q + \sum_{i \in \boldsymbol{W}'} \mu_i \boldsymbol{a}_i = \mathbf{0}.$$

把式 (23.21)中的 ∇q 代入，得

$$\boldsymbol{B}\boldsymbol{d}' = \sum_{i \in \boldsymbol{W}'} (\lambda_i - \mu_i)\boldsymbol{a}_i + \lambda_k \boldsymbol{a}_k.$$

用 $(\boldsymbol{d}')^{\top}$ 左乘，并注意 $i \in \boldsymbol{W}'$ 时 $\langle \boldsymbol{a}_i, \boldsymbol{d}' \rangle = 0$，得到

$$(\boldsymbol{d}')^{\top} \boldsymbol{B} \boldsymbol{d}' = \lambda_k \langle \boldsymbol{a}_k, \boldsymbol{d}' \rangle.$$

左端为正，$\lambda_k < 0$，所以式 (23.22)成立。

最后，$\boldsymbol{d}'$ 是等式 QP 的最小点而 $\boldsymbol{d} = \mathbf{0}$ 可行，且最小点唯一，所以模型值严格小于零，即严格小于 $\boldsymbol{d} = \mathbf{0}$ 时的模型值。 ■

式 (23.22)的含义是，走 $\boldsymbol{d}'$ 时被释放的约束 k 严格变松，点确实离开了这条边，不会立刻违反它。图 23.7是例子中的这两个时刻。

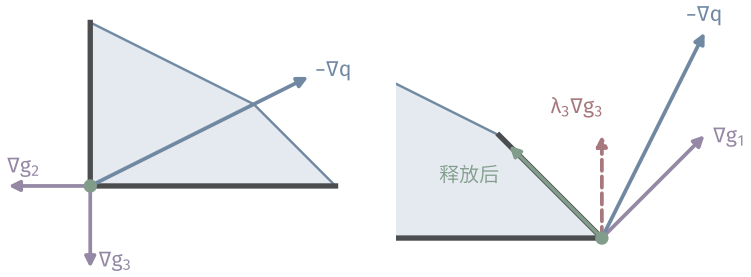


图 23.7 乘子的符号。蓝色箭头是 $-\nabla q$，紫色箭头是工作集约束的梯度，深灰粗线是工作集对应的边。(a) 原点处 $-\nabla q = (4,2)^{\top}$ 指向可行域内部，它分解到两个向外的梯度上时系数都是负的。(b) 顶点 $(3,0)^{\top}$ 处，$-\nabla q = \nabla g_1 + \lambda_3 \nabla g_3$，其中 $\lambda_1 = 1$，$\lambda_3 = -1$；红色虚线箭头是 $\lambda_3 \nabla g_3$。释放 g_3 后沿 g_1 的边（绿）走。

整个逻辑可以画成图 23.8。每一轮只改动工作集中的一条约束，或者加入一条，或者释放一条。

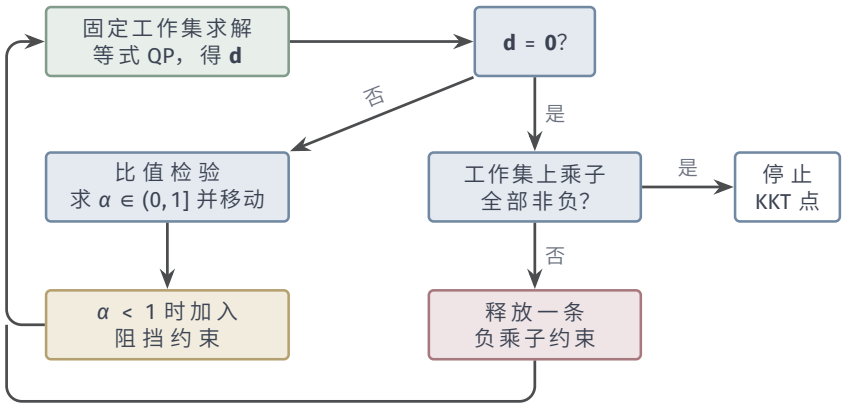


图 23.8 有效集法一轮的判断。先求步；步非零则做比值检验，受阻时加入一条约束；步为零则看乘子，全部非负时停止，否则释放一条负乘子约束。

变量

- $\boldsymbol{x}^{(t)} \in \mathbb{R}^n$：当前可行点。
- $\boldsymbol{W}$：工作集，下标集合，其大小不超过 n。
- $\boldsymbol{A}_{\boldsymbol{W}}$：以 $\boldsymbol{a}_i^{\top}$（$i \in \boldsymbol{W}$）为行的矩阵；$\boldsymbol{Z}_{\boldsymbol{W}}$：其零空间的基。
- $\boldsymbol{d}^{(t)} \in \mathbb{R}^n$：等式 QP 的解；$\lambda_i$（$i \in \boldsymbol{W}$）：工作集上的乘子。

初始化 取可行点 $\boldsymbol{x}^{(0)}$ 和一个工作集 $\boldsymbol{W}$，其约束在 $\boldsymbol{x}^{(0)}$ 处活动且梯度线性无关。例中取原点和它处的两条活动约束：

$$\boldsymbol{x}^{(0)} = (0, 0)^{\top}, \qquad \boldsymbol{W} = \{2, 3\}.$$

目标值是 $q(\boldsymbol{x}^{(0)}) = 10$。

每轮更新

1. 求步。由式 (23.12)，取 $\boldsymbol{h} = \boldsymbol{0}$，等式 QP 的解是

$$\boldsymbol{d}^{(t)} = -\boldsymbol{Z}_{\boldsymbol{W}} \left(\boldsymbol{Z}_{\boldsymbol{W}}^{\top} \boldsymbol{B} \boldsymbol{Z}_{\boldsymbol{W}} \right)^{-1} \boldsymbol{Z}_{\boldsymbol{W}}^{\top} \left(\boldsymbol{B}\boldsymbol{x}^{(t)} + \boldsymbol{c} \right). \tag{23.23}$$

   例中第一轮 $\boldsymbol{W} = \{2, 3\}$，零空间只有零向量，$\boldsymbol{d}^{(0)} = \boldsymbol{0}$。

2. 若 $\boldsymbol{d}^{(t)} = \boldsymbol{0}$，由式 (23.21)解出 λ_i。行满秩时，用 $\boldsymbol{A}_{\boldsymbol{W}}$ 左乘即得

$$\boldsymbol{\lambda}_{\boldsymbol{W}} = -\left(\boldsymbol{A}_{\boldsymbol{W}} \boldsymbol{A}_{\boldsymbol{W}}^{\top} \right)^{-1} \boldsymbol{A}_{\boldsymbol{W}} \left(\boldsymbol{B}\boldsymbol{x}^{(t)} + \boldsymbol{c} \right). \tag{23.24}$$

   全部非负就停止；否则从 $\boldsymbol{W}$ 中去掉乘子最小的约束，令 $\boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)}$，进入下一轮。

例中第一轮 $\nabla q = (-4,-2)^{\top}$，方程 (23.21)给出 $\lambda_2 = -4$，$\lambda_3 = -2$。两个都是负的，释放 g_2，得 $\boldsymbol{W} = \{3\}$，$\boldsymbol{x}^{(1)} = \boldsymbol{x}^{(0)}$。

3. 若 $\boldsymbol{d}^{(t)} \neq \boldsymbol{0}$，由式 (23.20)算 $\alpha^{(t)}$，并移动到

$$\boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} + \alpha^{(t)} \boldsymbol{d}^{(t)}. \tag{23.25}$$

若 $\alpha^{(t)} < 1$，把阻挡约束加入 $\boldsymbol{W}$。

例中第二轮 $\boldsymbol{W} = \{3\}$，$\boldsymbol{Z}_{\boldsymbol{W}} = (1,0)^{\top}$，由式 (23.23)得 $\boldsymbol{d}^{(1)} = (4,0)^{\top}$。比值检验只看 $\langle \boldsymbol{a}_i, \boldsymbol{d} \rangle > 0$ 的 g_1 和 g_4：

$$g_1 : \ \frac{3}{4} = 0.75, \qquad g_4 : \ \frac{4}{4} = 1.$$

于是 $\alpha^{(1)} = 0.75$，受阻于 g_1，得

$$\boldsymbol{x}^{(2)} = (3,0)^{\top}, \qquad \boldsymbol{W} = \{1,3\}, \qquad q(\boldsymbol{x}^{(2)}) = 2.5.$$

第三轮零空间又只有零向量，$\boldsymbol{d}^{(2)} = \boldsymbol{0}$。此时 $\nabla q = (-1,-2)^{\top}$，乘子满足

$$\begin{bmatrix} -1 \\ -2 \end{bmatrix} + \lambda_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \lambda_3 \begin{bmatrix} 0 \\ -1 \end{bmatrix} = \boldsymbol{0}.$$

第一行给 $\lambda_1 = 1$，第二行给 $\lambda_3 = -1$。释放 g_3，得 $\boldsymbol{W} = \{1\}$，$\boldsymbol{x}^{(3)} = \boldsymbol{x}^{(2)}$。

第四轮 $\boldsymbol{Z}_{\boldsymbol{W}} = (1,-1)^{\top}$，$\boldsymbol{Z}_{\boldsymbol{W}}^{\top}\boldsymbol{Z}_{\boldsymbol{W}} = 2$，$\boldsymbol{Z}_{\boldsymbol{W}}^{\top}\nabla q = 1$。由式 (23.23)，

$$\boldsymbol{d}^{(3)} = -\frac{1}{2}\begin{bmatrix} 1 \\ -1 \end{bmatrix} = (-0.5,\ 0.5)^{\top}.$$

比值检验中 g_2 的比值是 $3/0.5 = 6$，g_4 的比值是 $1/0.5 = 2$，都大于 1，所以走满一步：

$$\boldsymbol{x}^{(4)} = (2.5,\ 0.5)^{\top}, \qquad q(\boldsymbol{x}^{(4)}) = 2.25.$$

4. 重复第 1 至 3 步，直到第 2 步发现乘子全部非负。

例中第五轮 $\boldsymbol{W} = \{1\}$，此时 $\nabla q = (-1.5,-1.5)^{\top}$ 与 $\boldsymbol{Z}_{\boldsymbol{W}}$ 正交，所以这一轮的步为零。乘子由下式确定：

$$\nabla q + \lambda_1 (1,1)^{\top} = \boldsymbol{0}, \qquad \lambda_1 = 1.5 \geq 0.$$

乘子非负，停止。

最终得到 $\boldsymbol{x}^{\star} = (2.5, 0.5)^{\top}$，$g_1$ 是唯一的活动约束，影子价格 $\lambda_1 = 1.5$。路径如图 23.9，每个停留的点上都发生一次工作集的变动。

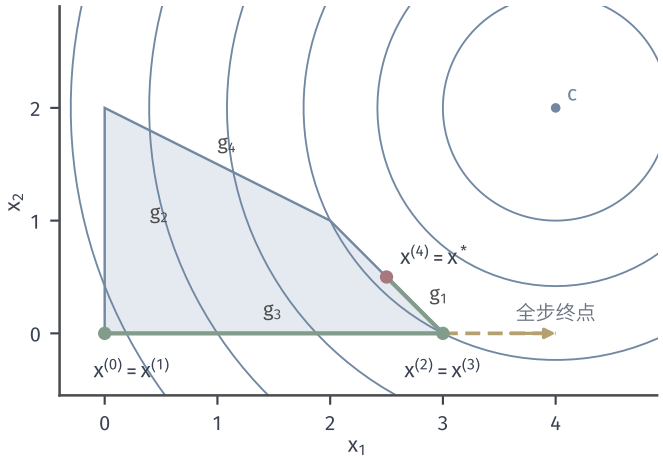


图 23.9 例 (23.18)上有效集法的路径（绿）。浅蓝区域是可行域，蓝色同心圆是 q 的等高线，蓝点是无约束最小点 $\boldsymbol{c}^{\circ}$。沿 g_3 的边本想走到 $(4,0)^{\mathsf{T}}$（黄色虚线），在 $(3,0)^{\mathsf{T}}$ 被 g_1 挡住；释放 g_3 后沿 g_1 走到红点，算法结束。

为什么有限步结束 工作集的取法只有有限多种，只要同一个工作集不会被重复“解完”，算法就会停。

定理 23.6 有效集法的有限终止 设 $\boldsymbol{B} \succ \boldsymbol{0}$，工作集中的约束梯度始终线性无关，并且每个 $\boldsymbol{d}^{(t)} \neq \boldsymbol{0}$ 的轮次都有 $\alpha^{(t)} > 0$。则算法在有限轮后停在问题 (23.17)的全局最优解。

证明 称 $\boldsymbol{d}^{(t)} = \boldsymbol{0}$ 的轮次为到站。两次到站之间，$\boldsymbol{W}$ 只增不减，所以至多有 n 轮比值检验，否则 $\boldsymbol{W}$ 的大小超过 n，与线性无关矛盾。由此到站必然反复发生或算法停止。

下面说明工作集不会在两次到站时重复。到站时 $\boldsymbol{x}^{(t)}$ 是 q 在工作集约束所定义的仿射面上的唯一最小点，所以到站时的目标值由 $\boldsymbol{W}$ 决定。

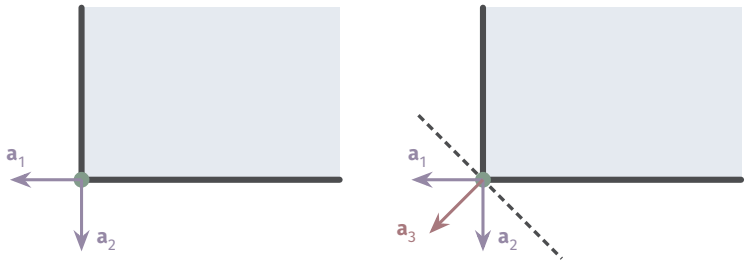
由引理 23.5，到站后释放一条约束得到的步非零，严格降低模型。凸二次函数沿下降方向走 $\alpha \in (0,1]$ 仍严格下降，而假设保证 $\alpha > 0$。所以相邻两次到站的目标值严格递减，同一个 $\boldsymbol{W}$ 不会出现两次。工作集的个数有限，算法必在有限轮后到站且乘子全部非负，此时 KKT 条件成立，由凸性得全局最优。 ■

定理要求每次移动的步长为正。这个条件失效时会发生什么，是下面要讨论的。

23.1 局部二次模型
23.2 等式 QP 的求解
23.3 有效集法（Active-Set）
23.3.1 工作集的更新
23.3.2 有效集法与 SQP
23.4 曲率的处理
23.5 更新的接受
23.6 模型的修复
23.7 收敛与计算成本
23.8 本章小结

退化、平局与热启动 假设例中 g_4 改成 $x_1 + 2x_2 \le 3$。第二轮的比值检验中，g_1 和 g_4 的比值都是 0.75，出现平局，只能加入一条，另一条在下一点也活动却不在工作集中。

这一点已经是退化的：图 23.10(b) 那样，过一点的活动约束多于 n 条或梯度线性相关。这时比值检验可能算出 $\alpha^{(t)} = 0$，点不动，只有工作集换了一条。一连串这样的零步有可能转回原来的工作集，形成循环，定理的条件也就破坏了。



(a) (b)

图 23.10 顶点处的约束梯度。(a) 两条活动约束，紫色梯度线性无关，工作集的选取没有歧义。(b) 第三条约束（虚线）也经过同一点，三个梯度在平面内线性相关，工作集只能放下其中两条，走零步时点不动而工作集在变。

实用的防范办法有两类。一类是确定性的选取规则，例如第 3章的 Bland 规则，在平局和释放时都按下标的固定顺序挑选，避免转圈。另一类是给约束右端加很小的扰动，让重合的边界分开，结束后再回到原数据上核对。释放时取最负的乘子是常用的选择，但它本身不防止循环。

有效集法还有一个明显的长处。如果手里有一个接近解的工作集，从它开始往往几轮就结束，这叫**热启动**（warm start）。SQP 相邻两轮的 QP 数据只有微小变化，上一轮的工作集正是下一轮的好起点。内点法从内部出发，较难利用这种信息。每轮工作集只变一条约束，$\boldsymbol{K}$ 或 $\boldsymbol{Z}$ 的分解也可以用低秩修正更新，不必重新分解。

23.3.2 有效集法与 SQP

把有效集法用在局部 QP (23.4)上时，变量是 $\boldsymbol{d}$，$\boldsymbol{a}_i = \nabla g_i^{(t)}$，$b_i = -g_i^{(t)}$。本小节要回答的问题是：这样得到的工作集，和原问题解处真正活动的约束是什么关系？

工作集属于当前的线性化 QP 先看一个带不等式的例子，把问题 (23.1)的约束放宽，再加两条线性约束：

$$\begin{aligned}&\min_{\boldsymbol{x}} \ -x_1 - x_2\\ &\text{s.t.} \quad g_1 = x_1^2 + x_2^2 - 2 \le 0, \quad g_2 = x_2 - 1.2 \le 0, \quad g_3 = -x_1 \le 0.\end{aligned} \tag{23.26}$$

解仍是 $(1,1)^{\top}$，只有 g_1 活动，乘子 $\lambda_1^{\star} = 1/2$。下面用精确的 Lagrange Hessian 和全步长，从 $\boldsymbol{x}^{(0)} = (0.5, 1.7)^{\top}$、$\boldsymbol{\lambda}^{(0)} = (1,0,0)^{\top}$ 出发。

第一轮 $\boldsymbol{B}^{(0)} = 2\lambda_1^{(0)}\boldsymbol{I} = 2\boldsymbol{I}$，约束的值和线性化约束是

$$\begin{gathered}g_1 = 1.14, \qquad g_2 = 0.5, \qquad g_3 = -0.5,\\ 1.14 + d_1 + 3.4\,d_2 \le 0, \qquad 0.5 + d_2 \le 0, \qquad -0.5 - d_1 \le 0.\end{gathered}$$

模型的目标是 $-d_1 - d_2 + d_1^2 + d_2^2$。先试工作集 $\{2\}$：取 $d_2 = -0.5$，d_1 的最优值是 0.5。检验其余约束，线性化的 g_1 值是

$$1.14 + 0.5 + 3.4 \times (-0.5) = -0.06 \le 0,$$

线性化的 g_3 值是 $-1 \le 0$, 都满足。乘子由第二个驻定方程 $-1 + 2d_2 + \hat{\lambda}_2 = 0$ 得 $\hat{\lambda}_2 = 2 \ge 0$。所以 QP 的解是

$$\boldsymbol{d}^{(0)} = (0.5,\ -0.5)^{\top}, \qquad \hat{\boldsymbol{\lambda}} = (0,\ 2,\ 0)^{\top}, \qquad \boldsymbol{x}^{(1)} = (1,\ 1.2)^{\top}.$$

这一步说明了两件事。其一，这一轮的工作集是 $\{2\}$，而原问题解处活动的是 $\{1\}$：工作集属于这一轮的线性化 QP，不是对原问题的最终判断。其二，$\boldsymbol{d}^{(0)}$ 满足全部线性化约束，新点却有

$$g_1(\boldsymbol{x}^{(1)}) = 1 + 1.44 - 2 = 0.44 > 0.$$

QP 可行不代表原问题可行，图 23.11(a) 画的就是这个缺口：步落在线性化的半平面内，却冲出了圆。

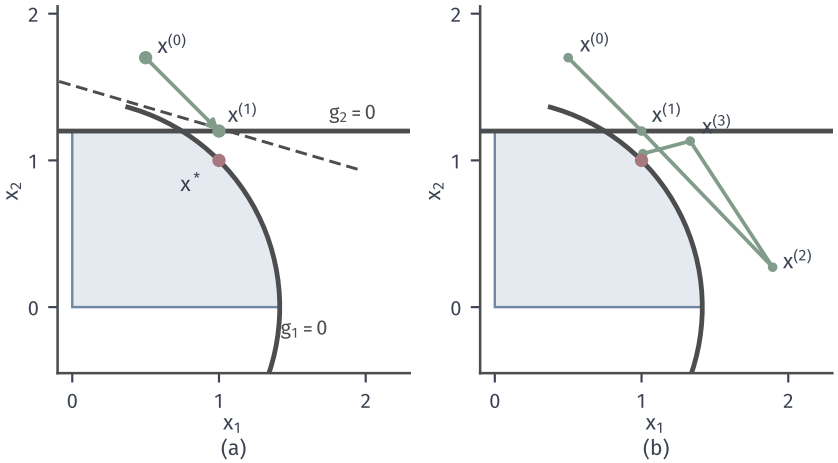


图 23.11 问题 (23.26)上的 SQP。浅蓝区域是真实可行域，深灰粗线是 g_1, g_2 的边界，绿色折线是迭代路径，红点是解。(a) 第一步，虚线是 g_1 在 $\boldsymbol{x}^{(0)}$ 的线性化边界，$\boldsymbol{x}^{(1)}$ 满足线性化约束但在圆外。(b) 前五步的路径：工作集先后是 $\{2\}$ 与 $\{1\}$，迭代点在前几轮都不可行。

第二轮的乘子估计是 $\lambda_1^{(1)} = 0$，于是 $\nabla^2_{\boldsymbol{xx}}\mathcal{L} = \boldsymbol{0}$，子问题退化成线性规划。为了让子问题仍有曲率，这里临时取 $\boldsymbol{B}^{(1)} = 0.1\,\boldsymbol{I}$，这类修正下一节专门讨论。此后 QP 选中的工作集稳定为 $\{1\}$，乘子很快接近 $1/2$。图 23.12列出各轮约束值和工作集。

	t=0	t=1	t=2	t=3	t=4	t=5
g_1	1.14	0.44	1.66	1.05	0.11	2e-03
g_2	0.50	0	-0.93	-0.07	-0.15	-0.20
g_3	-0.50	-1.00	-1.89	-1.33	-1.01	-1.00

图 23.12 问题 (23.26)各轮的约束值 $g_i(\boldsymbol{x}^{(t)})$，正值（红字）表示违反原约束，绿色格表示该约束在这一轮 QP 的最优工作集中。第一轮之后工作集稳定为 $\{1\}$，而 g_1 的违反量要到后几轮才降下来。

什么时候能认出解处的活动集 图 23.12的现象并不偶然。在解附近，QP 的最优工作集会固定下来，且正好是原问题的活动集，此后的 SQP 就成了只含等式的 SQP，上一节的结论都可以用。先复述第 17章的三个条件。设 $(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 是 KKT 点，$\boldsymbol{S}^\star$ 是 $\boldsymbol{x}^\star$ 处活动的不等式下标集。

- 约束资格（LICQ）：活动不等式和全部等式的梯度在 $\boldsymbol{x}^\star$ 处线性无关。
- 严格互补：对每个 $i \in \boldsymbol{S}^\star$，有 $\lambda_i^\star > 0$。
- 二阶充分条件：$\nabla^2_{\boldsymbol{xx}}\mathcal{L}$ 在解处沿活动约束梯度的零空间正定。在严格互补下，这就是该章临界锥上的二阶条件。

23.1 局部二次模型
23.2 等式 QP 的求解
23.3 有效集法（Active-Set）
23.4 曲率的处理
23.4.1 Hessian 修正
23.4.2 拟 Newton 近似
23.5 更新的接受
23.6 模型的修复
23.7 收敛与计算成本
23.8 本章小结

定理 23.7　解附近的活动集识别　设上述三个条件成立。对任意有界的对称矩阵族 $\{\boldsymbol{B}\}$，若它们在活动约束零空间上的约化矩阵一致正定，则存在 $(\boldsymbol{x}^\star,\boldsymbol{\lambda}^\star,\boldsymbol{\nu}^\star)$ 的邻域，使得当当前点与乘子都在此邻域内时，QP (23.4)有一个靠近 $\mathbf{0}$ 的严格局部解 $\boldsymbol{d}$，其活动集恰为 $\boldsymbol{S}^\star$，乘子靠近 $(\boldsymbol{\lambda}^\star,\boldsymbol{\nu}^\star)$。

证明　把 $\boldsymbol{S}^\star$ 中的不等式和全部等式都当作等式，写出方程 (23.9)，其解记为 $(\boldsymbol{d},\hat{\boldsymbol{\lambda}}_{\boldsymbol{S}^\star},\hat{\boldsymbol{\nu}})$，并令 $\boldsymbol{S}^\star$ 以外的乘子为零。

由 LICQ 和约化矩阵的一致正定，KKT 矩阵在该邻域内一致可逆（定理 23.3的论证与连续性）。在 $(\boldsymbol{x}^\star,\boldsymbol{\lambda}^\star,\boldsymbol{\nu}^\star)$ 处方程右端使解为 $\boldsymbol{d}=\mathbf{0}$，乘子为 $(\boldsymbol{\lambda}^\star_{\boldsymbol{S}^\star},\boldsymbol{\nu}^\star)$。方程右端连续，而 $\boldsymbol{B}\boldsymbol{d}$ 随 $\boldsymbol{d}\to\mathbf{0}$ 趋于零，所以邻域足够小时 $\boldsymbol{d}$ 靠近 $\mathbf{0}$，乘子靠近其真值。

现在逐条核对条件 (23.7)。严格互补使 $\hat{\lambda}_i>0$（$i\in\boldsymbol{S}^\star$），乘子符号成立。对 $i\notin\boldsymbol{S}^\star$，有 $g_i(\boldsymbol{x}^\star)<0$，由连续性 $g_i+\langle\nabla g_i,\boldsymbol{d}\rangle<0$，这些约束严格满足。所以 $\boldsymbol{d}$ 是 QP 的 KKT 点，活动集恰为 $\boldsymbol{S}^\star$。

最后，活动约束的乘子严格为正，且 $\boldsymbol{B}$ 在其零空间上正定，所以二阶充分条件对这个 QP 成立，$\boldsymbol{d}$ 是严格局部解。 ■

这个定理只断言“存在这样一个解”。QP 非凸时可能还有别的局部解，求解器未必返回这一个；若从上一轮的工作集热启动，实际中通常就落在这一个上。条件各有其用：缺少严格互补时，$\lambda_i^\star=0$ 的约束可能在相邻两轮时进时出；缺少约束资格时乘子不唯一，方程组可能接近奇异。

原问题的检查不能省　工作集稳定是解附近的现象，远离解时它可能频繁变动。即使稳定了，QP 可行也只是切平面上的可行。所以有效集法解完子问题后，仍然要回到原问题检验新点的目标和约束，这正是第 23.5节的内容。

23.4 曲率的处理

式 (23.6)的矩阵在解附近很好，远离解时却可能不定。这就需要回答：$\boldsymbol{B}^{(t)}$ 既要反映真实的局部曲率，又要让子问题有意义、让步能被接受，这两者怎样兼顾？

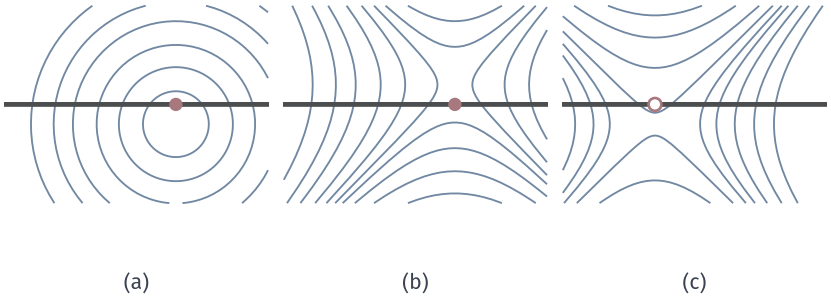
KKT 系统可解不等于模型是碗 先把两件容易混淆的事分开。设只有一条约束 $d_2 = 0$，即 $\boldsymbol{A} = (0, 1)$，线性项 $\boldsymbol{c} = (-0.6, 0.3)^{\mathsf{T}}$，比较三个矩阵：

$$\boldsymbol{B}_a = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \qquad \boldsymbol{B}_b = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}, \qquad \boldsymbol{B}_c = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}.$$

这里零空间由 $\boldsymbol{e}_1$ 张成，约化 Hessian 就是左上角的元素。三种情形下 KKT 矩阵都可逆，解都由 $B_{1,1} d_1 = 0.6$ 给出，对应的 $\boldsymbol{d}$ 分别是

$$(0.6,\ 0)^{\mathsf{T}}, \qquad (0.6,\ 0)^{\mathsf{T}}, \qquad (-0.6,\ 0)^{\mathsf{T}}.$$

图 23.13是这三个模型。情形 (a) 是凸的，解是最小点。情形 (b) 的 $\boldsymbol{B}$ 不定，整个二次目标不是凸的，可是沿约束直线它向上弯，解仍是约束上的最小点。情形 (c) 的 $\boldsymbol{B}$ 同样不定，沿直线却向下弯，解是约束上的最大点，模型沿直线无下界。



(a) (b) (c)

图 23.13 三个 KKT 矩阵都可逆的模型，蓝线是二次目标的等高线，深灰粗线是约束 $d_2 = 0$。(a) $\boldsymbol{B}$ 正定，解（红点）是最小点。(b) $\boldsymbol{B}$ 不定而约化 Hessian 为正，解仍是约束上的最小点。(c) 约化 Hessian 为负，KKT 系统的解（空心点）是约束上的最大点。

所以有三个不同的判断：KKT 矩阵可逆；约化 Hessian 正定；$\boldsymbol{B}$ 在全空间正定。第三个推出第二个，第二个在行满秩时推出第一个，反过来都不成立。整个二次目标凸不凸，本身不是 SQP 需要的条件。

这几件事可以通过分解读出来。矩阵的**惯性**（inertia）是其正、负、零特征值的个数。$\boldsymbol{A}$ 行满秩时可以证明，$\boldsymbol{K}$ 的惯性等于 $\boldsymbol{Z}^{\mathsf{T}}\boldsymbol{B}\boldsymbol{Z}$ 的惯性再各加上 p 个正、负特征值，证明要用一次合同变换，篇幅不长，读者可查阅专著[1]。因此约化 Hessian 正定当且仅当 $\boldsymbol{K}$ 恰有 n 个正特征值和 p 个负特征值。

用上面三个矩阵核对。这里 $n = 2$，$p = 1$，$\boldsymbol{K}_a$ 和 $\boldsymbol{K}_b$ 的惯性都是 $(2, 1, 0)$；$\boldsymbol{K}_c$ 的特征值是 -1 和 $(1 \pm \sqrt{5})/2$，惯性是 $(1, 2, 0)$，多出一个负特征值，正好标记了错误的曲率。

[1] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

23.1 局部二次模型
23.2 等式 QP 的求解
23.3 有效集法（Active-Set）
23.4 曲率的处理
23.4.1 Hessian 修正
23.4.2 拟 Newton 近似
23.5 更新的接受
23.6 模型的修复
23.7 收敛与计算成本
23.8 本章小结

子问题由什么方法求解，决定了实际要满足什么。表 23.3按求解器列出要求。

子问题的解法	对 $\boldsymbol{B}$ 的实际要求
直接解 KKT 系统	可逆即可解，是否最小点要另查惯性
零空间方法	约化 Hessian 正定
有效集法	每个工作集的约化 Hessian 正定
要求凸 QP 的内点法等	通常要求 $\boldsymbol{B}$ 半正定

表 23.3 不同子问题解法对曲率的要求。

23.4.1 Hessian 修正

负曲率的例子 乘子估计差得远时，精确的 $\boldsymbol{B}$ 就可能是错的。回到问题 (23.1)的 $\boldsymbol{x}^{(0)}=(1.5,0.5)^{\mathsf{T}}$，把乘子估计错成 $\nu=-1$，于是 $\boldsymbol{B}=2\nu\boldsymbol{I}=-2\boldsymbol{I}$，在任何方向上都向下弯。

KKT 系统依然可解。第一行是 $-2\boldsymbol{d}+\boldsymbol{g}+\hat{\nu}\boldsymbol{A}^{\mathsf{T}}=\boldsymbol{0}$，由此

$$\boldsymbol{d}=\frac{1}{2}\bigl(\boldsymbol{g}+\hat{\nu}\boldsymbol{A}^{\mathsf{T}}\bigr)=\frac{1}{2}\begin{bmatrix}3\hat{\nu}-1\\ \hat{\nu}-1\end{bmatrix}.$$

代入第二行 $\boldsymbol{A}\boldsymbol{d}=-0.5$，左端是 $5\hat{\nu}-2$，于是

$$\hat{\nu}=0.3,\qquad \boldsymbol{d}=(-0.05,\ -0.35)^{\mathsf{T}}.$$

这个步是否合用，要沿线性化约束看模型。把允许的步写成 $\boldsymbol{d}=\boldsymbol{d}_Y+s\boldsymbol{t}$，其中 $\boldsymbol{d}_Y=(-0.15,-0.05)^{\mathsf{T}}$ 是第 23.2节的法向段，$\boldsymbol{t}=(-1,3)^{\mathsf{T}}/\sqrt{10}$ 是虚线的单位方向。代入模型并利用 $\boldsymbol{d}_Y\perp\boldsymbol{t}$，得到

$$q(s)=0.175-0.632\,s-s^2.$$

上式对 s 向下弯，模型沿线性化约束没有下界。KKT 系统给出的 $\boldsymbol{d}$ 对应 $s\approx-0.316$，正是图 23.14红线的最高点。求解这个方程得到的是模型的最大点，把它当作下降步是错的。

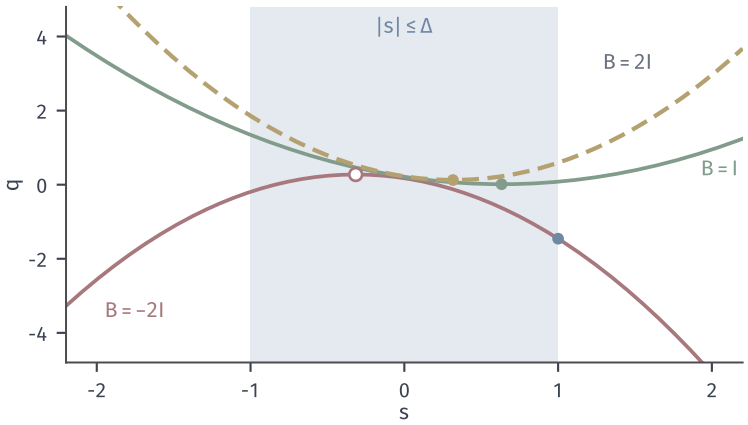


图 23.14 沿线性化约束的模型 $q(s)$，s 是沿虚线方向的位移。红线是 $\boldsymbol{B}=-2\boldsymbol{I}$，空心点是 KKT 系统的解，它是最大点。绿线、黄色虚线是移位后的 $\boldsymbol{B}=\boldsymbol{I}$ 与 $\boldsymbol{B}=2\boldsymbol{I}$，圆点是各自的最小点。浅蓝带是信赖域 $|s|\le\Delta=1$，蓝点是原模型在带内的最小点。

先核对模型是否无界 含不等式时情况稍有不同。不等式可能把下降方向挡住，QP 于是有解，可是解落在边界上，是负曲率推过去的，未必是好步。所以出现负曲率时要回答两个问题：子问题本身有没有下界，以及当前这个步是否适合接受。处理的办法有三类，它们改变的东西不同。

移位 第一种办法是把 $\boldsymbol{B}$ 换成 $\boldsymbol{B}+\tau\boldsymbol{I}$，这是第 7章修正 Newton 法的直接推广。取 τ 从小到大试，每次分解后检查惯性，直到约化 Hessian 正定。例中约化 Hessian 是 -2，需要 $\tau>2$。

取 $\tau=3$，就是 $\boldsymbol{B}=\boldsymbol{I}$。解 KKT 系统，第一行给 $\boldsymbol{d}=(1-3\hat{\nu},1-\hat{\nu})^{\mathsf{T}}$，第二行给 $4-10\hat{\nu}=-0.5$，于是

$$\hat{\nu}=0.45,\qquad \boldsymbol{d}=(-0.35,\ 0.55)^{\mathsf{T}}.$$

移位改的是模型本身，而且改的是所有方向的曲率。τ 越大，步越短、越偏向梯度方向。例中 $\tau=4$ 时步变成 $(-0.25,0.25)^{\mathsf{T}}$，图 23.14的黄线最低点比绿线更靠近 $s=0$，就是这个效果。

约化曲率修正 第二种办法只动约化 Hessian。在式 (23.12)中，把 $\boldsymbol{Z}^{\mathsf{T}}\boldsymbol{B}\boldsymbol{Z}$ 换成一个正定矩阵，比如把负特征值取绝对值，其他量不变。例中用 $|-2|=2$，右端不变，得到

$$s=\frac{0.632}{2}=0.316,\qquad \boldsymbol{d}=(-0.25,\ 0.25)^{\mathsf{T}}.$$

23.1 局部二次模型
23.2 等式 QP 的求解
23.3 有效集法（Active-Set）
23.4 曲率的处理
23.4.1 Hessian 修正
23.4.2 拟 Newton 近似
23.5 更新的接受
23.6 模型的修复
23.7 收敛与计算成本
23.8 本章小结

这里结果恰好和 $\tau = 4$ 相同，因为 $\boldsymbol{d}_Y$ 与 $\boldsymbol{t}$ 正交，$\boldsymbol{B}$ 又是单位阵的倍数。一般两者不同：约化修正不改变法向段，也保留了 $\boldsymbol{B}$ 在约束法方向上的信息。

信赖域限制 第三种办法不改模型，而是限制步能走多远，这是第 9章的想法。例中加 $|s| \le \Delta = 1$，模型在带内的最小点在边界 $s = 1$，那里的模型值是 -1.457，另一端 $s = -1$ 的模型值是 -0.193。

信赖域的好处是负曲率不用消除，它甚至被用来走得更远。约束优化中要多注意一件事：线性化约束和信赖域可能相互矛盾，它们的交集可能是空的。常见的处理是先取法向段，要求它只占信赖域的一部分，再在剩下的范围内取切向段。

做法	改变了什么	代价或风险
移位 $\boldsymbol{B} + \tau \boldsymbol{I}$	所有方向的曲率	反复分解，步偏向梯度
约化曲率修正	零空间内的曲率	需要显式的 $\boldsymbol{Z}$
信赖域	允许的步长范围	约束可能不相容

表 23.4 处理负曲率的三类办法。

这些办法各自改变了模型或步长范围。一个可解的 KKT 系统本身不能保证解是极小步，判断的依据只能是约化曲率或惯性。修正后的步还要经过第 23.5节的检验。

23.4.2 拟 Newton 近似

精确的式 (23.6)要求所有 $m + p + 1$ 个函数的二阶导数，这常常是 SQP 最贵也最难编写的一部分。第 8章的办法是从梯度之差积累曲率。本小节要解决的问题是：在约束问题上，这个差该怎么取，又该怎样保持近似矩阵可用？

割线信息 要近似的是 Lagrange 函数对 $\boldsymbol{x}$ 的 Hessian，所以差分的对象是 Lagrange 梯度。两点必须用同一组乘子，否则差分中混入乘子的变化，就不再是对 $\nabla^2_{\boldsymbol{xx}}\mathcal{L}$ 的测量。取新的乘子估计，令

$$\begin{aligned} \boldsymbol{s}^{(t)} &= \boldsymbol{x}^{(t+1)} - \boldsymbol{x}^{(t)}, \\ \boldsymbol{y}^{(t)} &= \nabla_{\boldsymbol{x}}\mathcal{L}(\boldsymbol{x}^{(t+1)}, \boldsymbol{\lambda}^{(t+1)}, \boldsymbol{\nu}^{(t+1)}) - \nabla_{\boldsymbol{x}}\mathcal{L}(\boldsymbol{x}^{(t)}, \boldsymbol{\lambda}^{(t+1)}, \boldsymbol{\nu}^{(t+1)}). \end{aligned} \tag{23.27}$$

BFGS 更新的公式与第 8章相同，这里省去上标，新矩阵记作 $\boldsymbol{B}^{+}$：

$$\boldsymbol{B}^{+} = \boldsymbol{B} - \frac{\boldsymbol{B}\boldsymbol{s}\boldsymbol{s}^{\top}\boldsymbol{B}}{\boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s}} + \frac{\boldsymbol{y}\boldsymbol{y}^{\top}}{\boldsymbol{s}^{\top}\boldsymbol{y}}. \tag{23.28}$$

例中取第一步 $\boldsymbol{s} = (-0.25, 0.25)^{\top}$，$\hat{\nu} = 0.5$，初始矩阵 $\boldsymbol{B} = 2\boldsymbol{I}$。这时 Lagrange 梯度是 $\boldsymbol{x} - (1,1)^{\top}$，由它在两点之差得到

$$\boldsymbol{y} = \boldsymbol{s} = (-0.25,\ 0.25)^{\top}, \qquad \boldsymbol{s}^{\top}\boldsymbol{y} = 0.125, \qquad \boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s} = 0.25.$$

代入式 (23.28)，并用 $\boldsymbol{B}\boldsymbol{s} = 2\boldsymbol{s}$，修正项化成 $\boldsymbol{s}\boldsymbol{s}^{\top}$ 的倍数：

$$\boldsymbol{B}^{+} = 2\boldsymbol{I} - 16\,\boldsymbol{s}\boldsymbol{s}^{\top} + 8\,\boldsymbol{s}\boldsymbol{s}^{\top} = \begin{bmatrix} 1.5 & 0.5 \\ 0.5 & 1.5 \end{bmatrix}.$$

可以核对割线条件 $\boldsymbol{B}^{+}\boldsymbol{s} = \boldsymbol{y}$：沿 $\boldsymbol{s}$ 的曲率从 2 变成了真实的 1，与 $\boldsymbol{s}$ 正交的方向仍保持 2，因为这一次测量对那个方向没有提供信息。

曲率条件与阻尼 无约束时，Wolfe 线搜索能保证 $\boldsymbol{s}^{\top}\boldsymbol{y} > 0$。约束问题却不同，$\nabla^{2}_{\boldsymbol{x}\boldsymbol{x}}\mathcal{L}$ 在解处也可能是不定的，这时走出来的 $\boldsymbol{s}$ 可能真的带着负曲率，不能靠步长选取来排除。如果 $\boldsymbol{s}^{\top}\boldsymbol{y} \le 0$，式 (23.28)会毁掉正定性。

阻尼 BFGS（damped BFGS）把 $\boldsymbol{y}$ 换成它和 $\boldsymbol{B}\boldsymbol{s}$ 的一个组合 $\boldsymbol{r}$，组合比例只在测量不够好时才起作用：

$$\begin{aligned} \boldsymbol{r} &= \theta\boldsymbol{y} + (1-\theta)\boldsymbol{B}\boldsymbol{s}, \\ \theta &= \begin{cases} 1, & \boldsymbol{s}^{\top}\boldsymbol{y} \ge 0.2\,\boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s}, \\ \dfrac{0.8\,\boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s}}{\boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s} - \boldsymbol{s}^{\top}\boldsymbol{y}}, & \text{否则}. \end{cases} \end{aligned} \tag{23.29}$$

然后在式 (23.28)中用 $\boldsymbol{r}$ 代替 $\boldsymbol{y}$。

第二种情形的 θ 恰好使 $\boldsymbol{s}^{\top}\boldsymbol{r} = 0.2\,\boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s} > 0$。把 θ 代入即可验证：

$$\boldsymbol{s}^{\top}\boldsymbol{r} = \boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s} + \theta\big(\boldsymbol{s}^{\top}\boldsymbol{y} - \boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s}\big) = \boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s} - 0.8\,\boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s}.$$

所以更新后的矩阵总保持正定。图 23.15按上例的 $\boldsymbol{s}^{\top}\boldsymbol{B}\boldsymbol{s} = 0.25$ 画出这条规则。设乘子为负，真实曲率是 -2，即 $\boldsymbol{y} = -2\boldsymbol{s}$，$\boldsymbol{s}^{\top}\boldsymbol{y} = -0.25$，于是

$$\theta = \frac{0.8 \times 0.25}{0.25 + 0.25} = 0.4, \qquad \boldsymbol{r} = 0.4\boldsymbol{s}.$$

沿 $\boldsymbol{s}$ 的曲率更新后是 $0.05/0.125 = 0.4$，即 $\boldsymbol{s}^{\top}\boldsymbol{r}$ 除以 $\boldsymbol{s}^{\top}\boldsymbol{s}$。它既不是测量到的 -2，也不是原来的 2。阻尼的代价是割线条件不再成立，矩阵不再记录真实的负曲率。

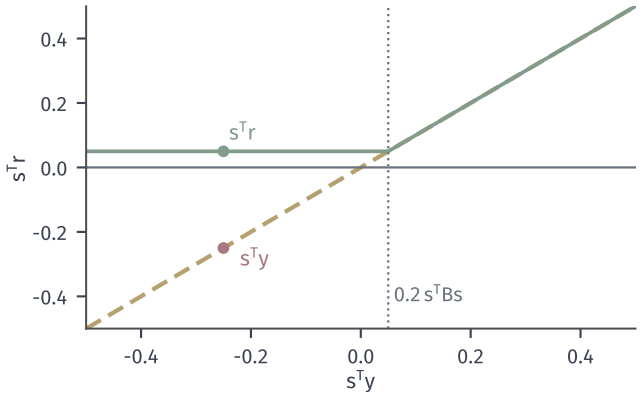


图 23.15 阻尼规则，$\boldsymbol{s}^{\mathsf{T}}\boldsymbol{B}\boldsymbol{s} = 0.25$。黄色虚线是未加处理的 $\boldsymbol{s}^{\mathsf{T}}\boldsymbol{y}$，绿线是阻尼后的 $\boldsymbol{s}^{\mathsf{T}}\boldsymbol{r}$，它在虚线竖线以左被托在 $0.2\,\boldsymbol{s}^{\mathsf{T}}\boldsymbol{B}\boldsymbol{s} = 0.05$。红点是测量值 -0.25，绿点是阻尼后的 0.05。

成本与速度 下面比较两种选择。精确 Hessian 每轮要算 $m + p + 1$ 个 Hessian，但步是 Newton 型的，轮数少。拟 Newton 只需要梯度，却维护一个稠密的 $n \times n$ 矩阵，破坏了 $\boldsymbol{K}$ 可能具有的稀疏结构，这时可以改用有限记忆的表示。

图 23.16是一个五变量问题上的比较，目标与约束为

$$f = \exp(x_1x_2x_3x_4x_5) - \tfrac{1}{2}(x_1^3 + x_2^3 + 1)^2,$$
$$h_1 = \|\boldsymbol{x}\|_2^2 - 10, \quad h_2 = x_2x_3 - 5x_4x_5, \quad h_3 = x_1^3 + x_2^3 + 1.$$

从 $(-1.8, 1.7, 1.9, -0.8, -0.8)^{\mathsf{T}}$ 与最小二乘乘子出发，精确 Hessian 的全步法 4 轮将误差降到 10^{-11} 以下；阻尼 BFGS（$\boldsymbol{B}^{(0)} = \boldsymbol{I}$，罚函数回溯，第 23.5.1节）前 18 轮都在攒曲率信息，步长常被缩短，之后几轮迅速下降，共需约 21 轮。

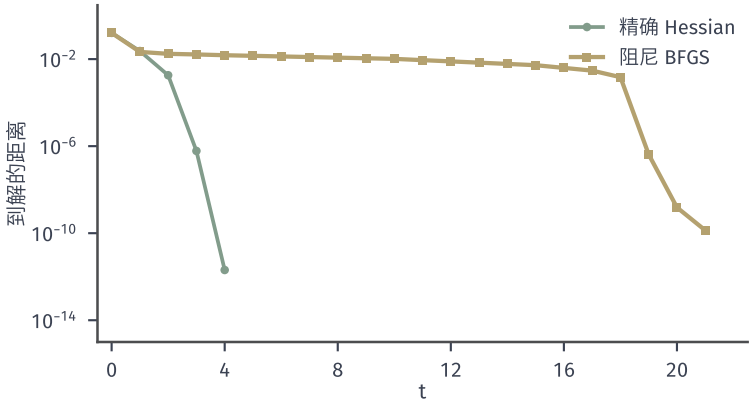


图 23.16 五变量问题上到解的距离。绿线是精确 Lagrange Hessian 的全步长 SQP，黄线是阻尼 BFGS 加罚函数回溯。两者起点相同，后者每轮不需要二阶导数。

23.1 局部二次模型
23.2 等式 QP 的求解
23.3 有效集法（Active-Set）
23.4 曲率的处理
23.5 更新的接受
23.5.1 罚函数线搜索
23.5.2 过滤器
23.6 模型的修复
23.7 收敛与计算成本
23.8 本章小结

这个对比只是一个例子，轮数的差距随问题而变。局部速度的结论还需要曲率近似的条件。记 $\boldsymbol{P}^{(t)}$ 是向 $\boldsymbol{A}^{(t)}$ 零空间的投影，$\boldsymbol{H}_{\mathcal{L}}^{\star}$ 是 Lagrange 函数在解处对 $\boldsymbol{x}$ 的 Hessian，需要的条件是

$$\lim_{t\to\infty}\frac{\|\boldsymbol{P}^{(t)}(\boldsymbol{B}^{(t)}-\boldsymbol{H}_{\mathcal{L}}^{\star})\boldsymbol{d}^{(t)}\|_2}{\|\boldsymbol{d}^{(t)}\|_2}=0. \tag{23.30}$$

它只要求沿步的方向、在切空间内近似准确，不要求 $\boldsymbol{B}^{(t)}$ 收敛到真实的 Hessian。这一点很重要，因为 $\boldsymbol{H}_{\mathcal{L}}^{\star}$ 可以不定，而正定的 BFGS 矩阵无法趋于不定矩阵；在切空间上 $\boldsymbol{H}_{\mathcal{L}}^{\star}$ 却是正定的，式 (23.30)仍可能成立。

23.5 更新的接受

QP 给出的步只在模型里是好的。把步放回非线性问题，凭什么判断它值得采用？

无约束时这个问题很简单，看目标有没有下降。约束问题有两个指标。第 23.2节的第三步目标从 -2.0588 升到 -2.0009，约束违反却从 0.119 降到 0.0018；而从圆上的点 $(1.4,0.2)^{\mathsf{T}}$ 走一个全步，目标从 -1.6 降到 -2.32，违反量却从 0 升到 0.72。两个指标常常冲突，必须有一条明确规则来评价进展。第 23.5.1小节把两者压成一个数，第 23.5.2小节把两者并排比较。

记约束的总违反量为

$$\theta(\boldsymbol{x})=\sum_{j=1}^{p}|h_j(\boldsymbol{x})|+\sum_{i=1}^{m}[g_i(\boldsymbol{x})]_+, \tag{23.31}$$

其中 $[u]_+=\max\{u,0\}$。

23.5.1 罚函数线搜索

评价函数 把目标和违反量加起来，用一个权重 $\rho>0$ 换算两者的单位，得到

$$\phi_\rho(\boldsymbol{x})=f(\boldsymbol{x})+\rho\,\theta(\boldsymbol{x}). \tag{23.32}$$

这是第 22章的 ℓ_1 精确惩罚函数，在这里它的角色是判断步的好坏，称为**评价函数**（merit function）。那一章的结论是：若 $\boldsymbol{x}^\star$ 满足二阶充分条件，且权重大于乘子的最大绝对值，则 $\boldsymbol{x}^\star$ 是 ϕ_ρ 的严格局部最小点。乘子是约束的影子价格，权重就是愿意为单位违反付的罚款，罚款低于影子价格，违约反而划算。

ϕ_ρ 在 $h_j=0$ 或 $g_i=0$ 处不可微，但沿任意方向的方向导数存在。记 $D(\phi_\rho;\boldsymbol{d})$ 为它在 $\boldsymbol{x}^{(t)}$ 处沿 $\boldsymbol{d}$ 的方向导数。下面的引理告诉我们，QP 的解在什么时候是下降方向。

引理 23.8 QP 步的下降性 设 $(\boldsymbol{d}, \hat{\boldsymbol{\lambda}}, \hat{\boldsymbol{\nu}})$ 满足条件 (23.7)，则

$$D(\phi_\rho; \boldsymbol{d}) \le -\boldsymbol{d}^{\top} \boldsymbol{B}^{(t)} \boldsymbol{d} - \left(\rho - \max\{\|\hat{\boldsymbol{\nu}}\|_\infty, \|\hat{\boldsymbol{\lambda}}\|_\infty\}\right) \theta(\boldsymbol{x}^{(t)}). \tag{23.33}$$

证明 分别计算 θ 和 f 的方向导数。先看等式项。线性化约束给出 $\langle \nabla h_j, \boldsymbol{d} \rangle = -h_j$。若 $h_j \neq 0$，则 $|h_j|$ 的方向导数是 h_j 的符号乘以 $\langle \nabla h_j, \boldsymbol{d} \rangle$，等于 $-|h_j|$；若 $h_j = 0$，则 $\langle \nabla h_j, \boldsymbol{d} \rangle = 0$，方向导数为 0。两种情况都等于 $-|h_j|$。

再看不等式项，线性化约束给出 $\langle \nabla g_i, \boldsymbol{d} \rangle \le -g_i$。若 $g_i > 0$，$[g_i]_+$ 的方向导数是 $\langle \nabla g_i, \boldsymbol{d} \rangle \le -[g_i]_+$；若 $g_i = 0$，方向导数是 $[\langle \nabla g_i, \boldsymbol{d} \rangle]_+ = 0$；若 $g_i < 0$，方向导数是 0。三种情况都不超过 $-[g_i]_+$。把这些加起来，得到

$$D(\theta; \boldsymbol{d}) \le -\theta(\boldsymbol{x}^{(t)}).$$

然后看目标。用 $\boldsymbol{d}^{\top}$ 左乘式 (23.7)第一行，再用线性化约束和互补条件换掉 $\boldsymbol{A}\boldsymbol{d}$ 和 $\boldsymbol{G}\boldsymbol{d}$：

$$\begin{aligned} \langle \nabla f, \boldsymbol{d} \rangle &= -\boldsymbol{d}^{\top} \boldsymbol{B} \boldsymbol{d} - \hat{\boldsymbol{\nu}}^{\top} \boldsymbol{A} \boldsymbol{d} - \hat{\boldsymbol{\lambda}}^{\top} \boldsymbol{G} \boldsymbol{d} \\ &= -\boldsymbol{d}^{\top} \boldsymbol{B} \boldsymbol{d} + \hat{\boldsymbol{\nu}}^{\top} \boldsymbol{h} + \hat{\boldsymbol{\lambda}}^{\top} \boldsymbol{g}. \end{aligned}$$

最后估计两个内积。第一个用 Hölder 不等式，第二个先用 $\hat{\boldsymbol{\lambda}} \ge \boldsymbol{0}$ 把 $\boldsymbol{g}$ 放大成 $[\boldsymbol{g}]_+$，再用 Hölder 不等式：

$$\begin{aligned} \hat{\boldsymbol{\nu}}^{\top} \boldsymbol{h} &\le \|\hat{\boldsymbol{\nu}}\|_\infty \|\boldsymbol{h}\|_1, \\ \hat{\boldsymbol{\lambda}}^{\top} \boldsymbol{g} &\le \hat{\boldsymbol{\lambda}}^{\top} [\boldsymbol{g}]_+ \le \|\hat{\boldsymbol{\lambda}}\|_\infty \|[\boldsymbol{g}]_+\|_1. \end{aligned}$$

合起来，

$$\langle \nabla f, \boldsymbol{d} \rangle \le -\boldsymbol{d}^{\top} \boldsymbol{B} \boldsymbol{d} + \max\{\|\hat{\boldsymbol{\nu}}\|_\infty, \|\hat{\boldsymbol{\lambda}}\|_\infty\} \theta(\boldsymbol{x}^{(t)}).$$

ϕ_ρ 的方向导数是 $\langle \nabla f, \boldsymbol{d} \rangle$ 与 $\rho D(\theta; \boldsymbol{d})$ 之和，式 (23.33)成立。 ■

引理说明，当 ρ 超过 QP 乘子的最大绝对值，并且 $\boldsymbol{d}^{\top} \boldsymbol{B} \boldsymbol{d}$ 为正时，$\boldsymbol{d}$ 是 ϕ_ρ 的下降方向。这里的正性只需在 $\boldsymbol{d}$ 上成立。$\boldsymbol{d}^{\top} \boldsymbol{B} \boldsymbol{d}$ 可能为负时，条件要通过第 23.4节的修正来保证。

权重的两难 式 (23.33)要求 ρ 足够大，但 ρ 并不是越大越好。看问题 (23.1)沿射线 $x_1 = x_2 = s$ 的情形，此时

$$\phi_\rho(s, s) = -2s + \rho\,|2s^2 - 2|.$$

在 $s > 1$ 上，ϕ_ρ 的导数是 $-2 + 4\rho s$。$\rho = 0.1$ 时导数在 $s = 5$ 才变号，评价函数在 $(5, 5)$ 有局部最小值，其值 -5.2 比解处的 -2 还小。沿着 $\phi_{0.1}$ 下降会被带到严重违约的地方。

$s = 1$ 处的右导数是 $-2 + 4\rho$，要它为正需要 $\rho > 1/2 = \nu^\star$，这正是权重要超过乘子的具体含义。图 23.17比较了三种权重。权重过大时，ϕ_ρ 在约束面两侧形成很陡的峡谷，任何离开约束面的步，即使只离开 $\|\boldsymbol{d}\|_2^2$ 这么多，也要付很高的代价，步长于是被压得很小，迭代只能贴着约束面慢慢挪。

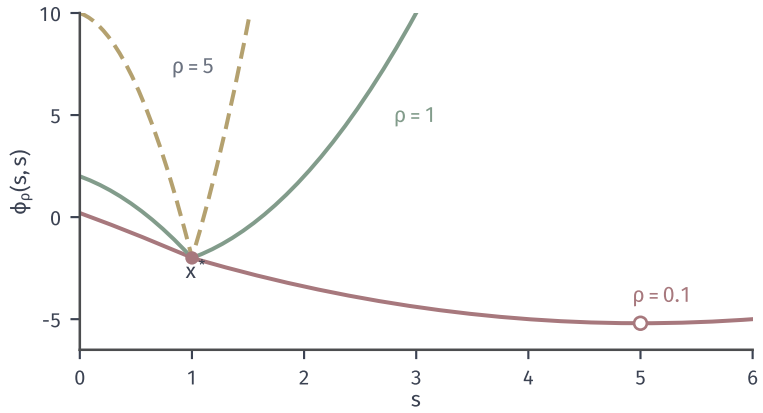


图 23.17 评价函数沿射线 $x_1 = x_2 = s$ 的形状。红线 $\rho = 0.1$ 低于乘子，空心点 $(5, 5)$ 是错误的局部最小点；绿线 $\rho = 1$ 在解 $s = 1$（红点）处形成拐点；黄色虚线 $\rho = 5$ 的峡谷很陡。

实际算法动态调整权重。常用规则是每轮令 ρ 不小于当前 QP 乘子的最大绝对值再加一个裕量 $\delta > 0$：

$$\rho^{(t)} \geq \max\{\|\hat{\boldsymbol{\nu}}\|_\infty, \|\hat{\boldsymbol{\lambda}}\|_\infty\} + \delta. \tag{23.34}$$

权重只升不降时，迭代的后期可能一直背着远离解时抬高的权重，因此实现中也允许有控制地下调。

主要思想 有了下降方向，就和无约束问题一样回溯。从 $\alpha = 1$ 开始试，直到满足充分下降条件：

$$\phi_\rho(\boldsymbol{x}^{(t)} + \alpha \boldsymbol{d}^{(t)}) \leq \phi_\rho(\boldsymbol{x}^{(t)}) + \eta\,\alpha\, D(\phi_\rho; \boldsymbol{d}^{(t)}), \tag{23.35}$$

其中 $\eta \in (0, 1/2)$。由于 ϕ_ρ 沿 $\boldsymbol{d}$ 在 $\alpha = 0$ 右侧的导数就是 D，小的 α 总能满足这个条件。

变量

- $\boldsymbol{x}^{(t)}$、$\boldsymbol{\nu}^{(t)}$：当前点与乘子；ρ：评价函数的权重。
- $\boldsymbol{d}^{(t)}$、$\hat{\boldsymbol{\nu}}$：QP 的解与乘子；D：ϕ_ρ 的方向导数。
- η：充分下降系数；$\alpha^{(t)}$：接受的步长。

初始化　给定 $\boldsymbol{x}^{(0)}$、$\boldsymbol{\nu}^{(0)}$、ρ 和 η。例中取圆上的一点，数据是

$$\boldsymbol{x}^{(0)} = (1.4,\ 0.2)^{\top}, \qquad \nu^{(0)} = 0.5, \qquad \rho = 2, \qquad \eta = 0.1.$$

这里 $h(\boldsymbol{x}^{(0)}) = 1.96 + 0.04 - 2 = 0$，点是可行的，$\phi_\rho(\boldsymbol{x}^{(0)}) = -1.6$。

每轮更新

1. 解 QP 得 $\boldsymbol{d}^{(t)}$ 和乘子。例中第一轮 $\boldsymbol{B} = \boldsymbol{I}$，$\boldsymbol{A} = (2.8, 0.4)$，$h = 0$，解得

$$\hat{\nu} = 0.4, \qquad \boldsymbol{d}^{(0)} = (-0.12,\ 0.84)^{\top}.$$

2. 按需要增大 ρ，并计算方向导数，即 $D = \langle \nabla f, \boldsymbol{d} \rangle - \rho\,\theta$（只含等式时）。例中 $\rho = 2 \geq \hat{\nu}$，$\theta = 0$，于是

$$D = \langle (-1, -1)^{\top}, \boldsymbol{d}^{(0)} \rangle = -0.72.$$

3. 令 $\alpha = 1$，当式 (23.35)不成立时令 $\alpha \leftarrow \alpha/2$。例中沿 $\boldsymbol{d}$ 有 $h(\boldsymbol{x} + \alpha \boldsymbol{d}) = 0.72\alpha^2$，$f(\boldsymbol{x} + \alpha \boldsymbol{d}) = -1.6 - 0.72\alpha$，所以

$$\phi_\rho(\alpha) = -1.6 - 0.72\,\alpha + 1.44\,\alpha^2.$$

   依次试三个步长，每个步长下左边是 ϕ_ρ 的值，右边是式 (23.35)的门槛：

$$\begin{aligned} \alpha = 1 &: \quad -0.88 > -1.672, \\ \alpha = 0.5 &: \quad -1.6 > -1.636, \\ \alpha = 0.25 &: \quad -1.69 \leq -1.618. \end{aligned}$$

   前两个被拒绝，第三个被接受，图 23.18画出了这三次试探。

4. 更新迭代点，乘子按式 (23.8)。例中第一轮

$$\boldsymbol{x}^{(1)} = (1.37,\ 0.41)^{\top}, \qquad \nu^{(1)} = 0.5 + 0.25\,(0.4 - 0.5) = 0.475.$$

23.1 局部二次模型
23.2 等式 QP 的求解
23.3 有效集法（Active-Set）
23.4 曲率的处理
23.5 更新的接受
23.5.1 罚函数线搜索
23.5.2 过滤器
23.6 模型的修复
23.7 收敛与计算成本
23.8 本章小结

第二轮 $h=0.045$，$\boldsymbol{d}^{(1)}\approx(-0.21767,0.67247)^{\mathsf T}$，$\alpha^{(1)}=0.25$；第三轮 $\alpha^{(2)}=0.5$；第四轮起 $\alpha^{(t)}=1$。

5. 按第 23.7节的残差判断是否停止。

最终 $\boldsymbol{x}^{(t)}$ 到达 $(1,1)^{\mathsf T}$，例中 $t=6$ 时到解的距离已低于 10^{-6}。

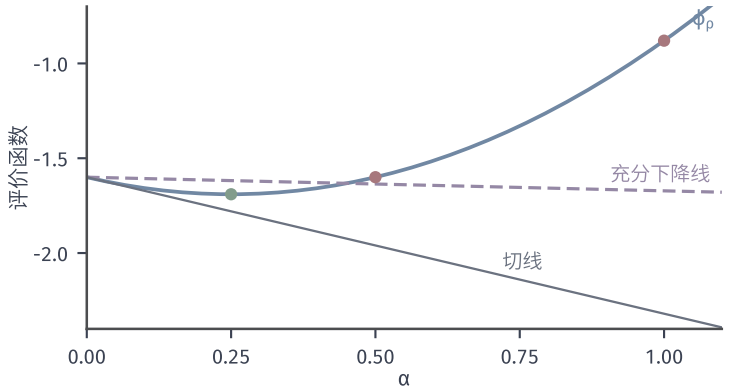


图 23.18　从 $\boldsymbol{x}^{(0)}=(1.4,0.2)^{\mathsf T}$ 沿 QP 步的评价函数，$\rho=2$。蓝线是 $\phi_\rho(\alpha)$，灰线是切线，紫色虚线是充分下降的门槛。红点 $\alpha=1$ 与 $\alpha=0.5$ 被拒绝，绿点 $\alpha=0.25$ 被接受。

这个例子还暗示了一个毛病。全步到达 $(1.28,1.04)^{\mathsf T}$，到解的距离从 0.894 缩到 0.283，明明很好，评价函数却把它拒绝了。原因及补救在第 23.6.2小节。

用信赖域代替线搜索　线搜索固定方向、调整步长。也可以用第 9章的方式固定一个半径，比较实际下降与模型预测，比值大则接受并放大半径，比值小则缩小半径。线性化的约束有可能与半径冲突，所以需要第 23.4.1小节提到的法向段与切向段的安排。信赖域版本可以自然处理负曲率，代价是实现更复杂。

23.5.2 过滤器

罚函数要预先定一个换算比例。本小节要回答的问题是：能不能不做这个换算，直接比较 θ 和 f 这两个指标？

基本想法　类比两人比赛：如果候选步在两个指标上都比某个历史记录差，就没有接受的理由；只要在某个指标上比所有记录都更好，就给它一个机会。把已接受的点的 (θ,f) 对存下来，这个集合称为**过滤器**（filter），记为 $\mathcal{F}$。

如果只要求“不被支配”，也就是不被某条记录在两个指标上同时压过，算法可能无限地取得微不足道的进步。设想 θ 的序列是 $1+1/k$，每一项

都比前一项略小，f 保持不变，每一步都不被支配，极限却是 $\theta = 1$，一个不可行的点。所以真正的条件要带裕量。

定义 23.9 过滤器的接受条件 给定 $\gamma \in (0,1)$，候选点 $\boldsymbol{x}^+$ 可被过滤器 $\mathcal{F}$ 接受，是指对每条记录 $(\theta_l, f_l) \in \mathcal{F}$，都有

$$\theta(\boldsymbol{x}^+) \le (1-\gamma)\theta_l \quad \text{或} \quad f(\boldsymbol{x}^+) \le f_l - \gamma\theta_l. \tag{23.36}$$

条件的后半式里的裕量是 $\gamma\theta_l$，它与违反量成比例。这样一来，要么约束违反按比例减小，要么目标确实下降一段距离，前面那个微小进步的序列不再能被接受。

用一组教学数据演示。取 $\gamma = 0.1$，三条记录为

$$(\theta_1, f_1) = (0.8, -2.6), \quad (\theta_2, f_2) = (0.3, -2.2), \quad (\theta_3, f_3) = (0.05, -1.9).$$

候选点 $A = (0.2, -2.4)$：对记录一，$0.2 \le 0.72$；对记录二，$0.2 \le 0.27$；对记录三，θ 不够小，但目标满足 $-2.4 \le -1.905$。三条都通过，接受。

候选点 $B = (0.4, -2.0)$：对记录一通过；对记录二，$0.4 > 0.27$，目标 $-2.0 > -2.23$，失败，拒绝。

候选点 $C = (0.295, -2.205)$ 看上去比记录二好一点，θ 和 f 都略小。但 $0.295 > 0.27$，$-2.205 > -2.23$，改进不够裕量，同样拒绝。图 23.19是这三个点的位置。

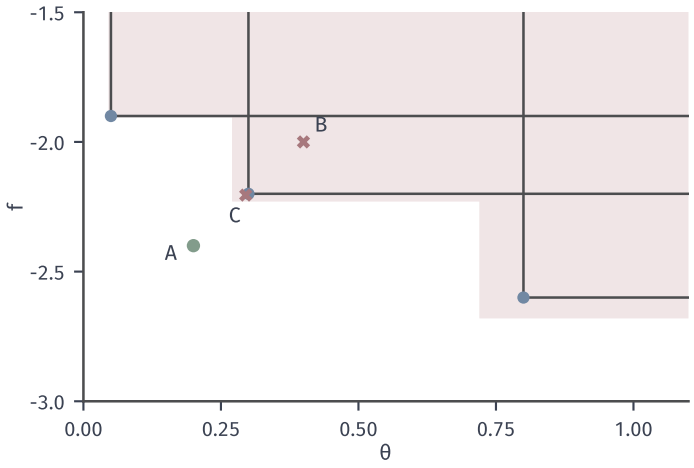


图 23.19 过滤器的 (θ, f) 平面，蓝点是三条记录，深灰线是它们支配的范围边界，红色浅底是带裕量 $\gamma = 0.1$ 的禁止区。绿点 A 被接受，红叉 B 和 C 被拒绝，其中 C 虽不被支配，但在裕量带内。

还需要什么 只靠式 (23.36)并不足以保证收敛到 KKT 点。还要回答三件事。

第一，局部切换。若迭代点已经几乎可行，而模型预测目标有明显下降，就不能只凭 θ 有所改善就接受，要转而要求目标满足类似式 (23.35)的充分下降，这样的步也不写入过滤器。否则算法可能收敛到一个可行但并不最优的点。

第二，什么时候写入记录。不满足上述切换条件而被接受的步，把当前点的 (θ, f) 写入过滤器，并删去被它支配的旧记录。这样禁止区只会扩大，同一区域不会被反复光顾。

第三，可行性恢复。回溯到很小的步长仍无法被接受，说明当前的线性化方向帮不上忙，这时转入下一节的恢复阶段。过滤器不能代替这些规则。

表 23.5总结了两种规则。

比较项	罚函数	过滤器
进展的度量	一个数 ϕ_ρ	两个数 (θ, f)
需要的参数	权重 ρ	裕量 γ、切换常数
主要风险	ρ 太小或太大	需额外的恢复与切换
历史信息	不保存	保存记录

表 23.5　罚函数线搜索与过滤器的比较。

23.6 模型的修复

前面两节都假定子问题有解，候选步也还算合用。本节处理两种不成立的情形，要回答的问题是：失败发生在哪一层，相应地该修什么？第一种失败发生在子问题上，线性化约束根本没有可行解，此时缩小步长毫无用处，因为连可以缩小的步都不存在。第二种失败发生在候选步上，QP 有解，步却被真实约束的弯曲挡住。

图 23.20按失败原因列出修复手段。只靠反复缩小步长处理所有问题，第一种情形无效，第二种情形则会拖慢收敛。

23.1 局部二次模型
23.2 等式 QP 的求解
23.3 有效集法（Active-Set）
23.4 曲率的处理
23.5 更新的接受
23.6 模型的修复
23.6.1 可行性恢复
23.6.2 二阶修正（补充）
23.7 收敛与计算成本
23.8 本章小结

23.1 局部二次模型
23.2 等式 QP 的求解
23.3 有效集法（Active-Set）
23.4 曲率的处理
23.5 更新的接受
23.6 模型的修复
23.6.1 可行性恢复
23.6.2 二阶修正（补充）
23.7 收敛与计算成本
23.8 本章小结

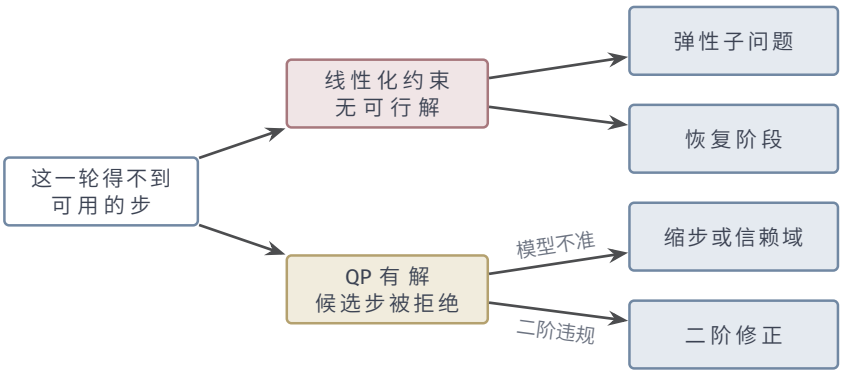


图 23.20 得不到可用的步时的两类原因及其修复。红框是子问题层面的失败，黄框是候选步层面的失败，蓝框是对应的处理。

23.6.1 可行性恢复

线性化约束可能相互矛盾 原问题可行，并不意味着它的线性化可行。看下面的问题：

$$\min_{\boldsymbol{x}} \frac{1}{2}\left((x_1-2)^2+x_2^2\right) \quad \text{s.t.} \quad h_1 = x_2 - x_1^2 = 0, \quad h_2 = x_2 - 1 = 0. \tag{23.37}$$

可行点只有 $(\pm 1, 1)^{\mathsf{T}}$，解是 $\boldsymbol{x}^\star = (1,1)^{\mathsf{T}}$。从原点出发，约束的值和 Jacobian 是

$$\boldsymbol{h}^{(0)} = (0,-1)^{\mathsf{T}}, \qquad \boldsymbol{A}^{(0)} = \begin{bmatrix} 0 & 1 \\ 0 & 1 \end{bmatrix}.$$

线性化约束成为 $d_2 = 0$ 和 $d_2 = 1$，两者矛盾。抛物线在顶点的切线是水平的，与直线 $x_2 = 1$ 平行，图 23.21(a) 里两条线永不相交。这里 $\boldsymbol{A}^{(0)}$ 的秩为 1，定理 23.3的前提失效。

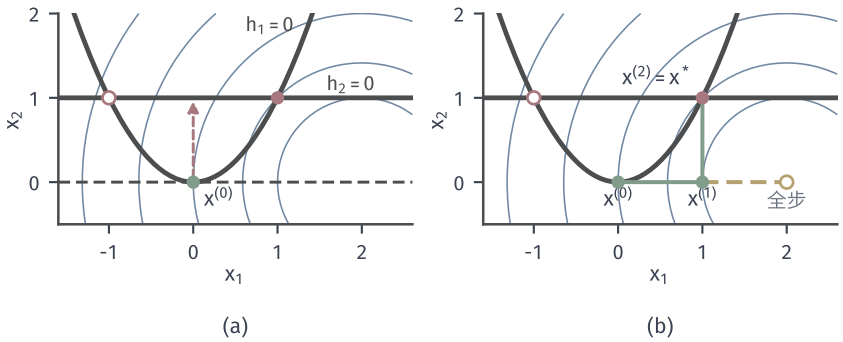


图 23.21 问题 (23.37)。深灰粗线是抛物线 $h_1 = 0$ 和直线 $h_2 = 0$，蓝线是目标的等高线，红点是解，空心点是另一个可行点。(a) 原点处抛物线的线性化（虚线）与 $h_2 = 0$ 平行，红色箭头表示两者之间的距离无法消除。(b) 弹性子问题的全步到 $(2,0)^{\mathsf{T}}$（黄色虚线），回溯到一半得 $\boldsymbol{x}^{(1)}$，下一轮的 QP 相容，一步到解。

弹性子问题 第一种修复是让约束可以有偿违反。给每条线性化约束加上非负的松弛变量，并在目标中按权重 ρ 收费，得到**弹性子问题**（elastic subproblem）：

$$\begin{aligned}\min_{\boldsymbol{d},\boldsymbol{v},\boldsymbol{w},\boldsymbol{u}}\quad & \langle \nabla f,\boldsymbol{d}\rangle+\frac{1}{2}\boldsymbol{d}^{\top}\boldsymbol{B}\boldsymbol{d}+\rho\big(\langle \mathbf{1},\boldsymbol{v}+\boldsymbol{w}\rangle+\langle \mathbf{1},\boldsymbol{u}\rangle\big)\\ \text{s.t.}\quad & \boldsymbol{h}+\boldsymbol{A}\boldsymbol{d}=\boldsymbol{v}-\boldsymbol{w},\\ & \boldsymbol{g}+\boldsymbol{G}\boldsymbol{d}\le \boldsymbol{u},\\ & \boldsymbol{v},\boldsymbol{w},\boldsymbol{u}\ge \mathbf{0}.\end{aligned}\tag{23.38}$$

它对任何数据都可行，取 $\boldsymbol{d}=\mathbf{0}$，松弛变量等于当前的违反量即可。

消去松弛变量，式 (23.38)就是在线性化约束上最小化 ℓ_1 惩罚的模型。第 22章的精确惩罚论证用在这个凸 QP 上，得到：当线性化约束相容且 ρ 大于 QP 乘子的最大绝对值时，松弛变量全为零，弹性解就是原来 QP 的解。所以可以总是求解弹性形式，不必先判断 QP 是否可行。

例中取 $\boldsymbol{B}^{(0)}=\boldsymbol{I}$，$\rho=1$。$\nabla f=(-2,0)^{\top}$，消去松弛变量后，模型是

$$-2d_1+\frac{1}{2}d_1^2+\frac{1}{2}d_2^2+|d_2|+|d_2-1|.$$

对 d_1 的最小化独立于 d_2，得 $d_1=2$。在 $0\le d_2\le 1$ 上两个绝对值之和恒为 1，这个区间内只剩 $\frac{1}{2}d_2^2$ 起作用，所以 $d_2=0$。于是

$$\boldsymbol{d}^{(0)}=(2,\,0)^{\top},\qquad \text{模型中的违反量}=1.$$

这一步并没有修好 h_2，只是把目标朝 x_1 方向推。候选点要用真实函数检验。起点的评价函数是 $\phi_1(\mathbf{0})=2+1=3$，全步的值和半步的值分别是

$$\phi_1(2,0)=0+4+1=5,\qquad \phi_1(1,0)=0.5+1+1=2.5.$$

全步因线性化高估而被拒绝,半步通过。于是 $\boldsymbol{x}^{(1)}=(1,0)^{\top}$。这里 $h_1=-1$，梯度变成 $(-2,1)$，第一行不再与第二行平行，线性化约束变成

$$-1-2d_1+d_2=0,\qquad -1+d_2=0.$$

它有唯一解 $\boldsymbol{d}^{(1)}=(0,1)^{\top}$，下一点恰好就是 $(1,1)^{\top}$。这里能一步到解有偶然的成分，两个约束两个变量，线性化解恰好落在抛物线上。要点是离开奇异点之后，线性化又恢复了相容，图 23.21(b) 是这条路径。

23.1 局部二次模型
23.2 等式 QP 的求解
23.3 有效集法（Active-Set）
23.4 曲率的处理
23.5 更新的接受
23.6 模型的修复
23.6.1 可行性恢复
23.6.2 二阶修正（补充）
23.7 收敛与计算成本
23.8 本章小结

恢复阶段 第二种修复更彻底。暂时不管 f，改而求解只关心可行性的问题：

$$\min_{\boldsymbol{x}} \ \theta(\boldsymbol{x}). \tag{23.39}$$

这称为**可行性恢复**（feasibility restoration）。当回溯到很小的步长仍不被过滤器或评价函数接受，或者弹性子问题的松弛变量长期不为零时，就转入恢复阶段。

恢复阶段的目标与原优化目标不同，这是必须记住的。它不保证目标下降，甚至可能把目标抬得很高。一旦违反量明显减小，并且新点能被过滤器接受或线性化重新相容，就停止恢复，在新点重建 SQP 模型，回到原来的目标上。

恢复失败说明不了什么 恢复阶段可能停在 θ 的局部最小点，而 θ 在那里仍然为正。这能证明原问题无可行解吗？不能。看单变量约束

$$h(x) = x^3 - 3x + 3 = 0.$$

$h'(x) = 3x^2 - 3$ 在 $x = 1$ 处为零，且 $h(1) = 1 > 0$，所以 $x = 1$ 是 $|h|$ 的局部最小点。从 $x = 1$ 附近出发的恢复过程会困在这里，而方程在 $x \approx -2.104$ 有实根。局部方法看到的只是局部信息，它只能报告“在这里找不到可行点”，要证明不可行需要全局的论证或对偶证书。

23.6.2 二阶修正（补充）

第 23.5.1小节留下一个疑点：好的全步被评价函数拒绝。本小节要回答的问题是：这种误判从何而来，怎样在不放弃这个步的前提下消除它？

好步被拒绝 下面的问题是弯曲约束上的典型例子：

$$\min_{\boldsymbol{x}} \ 2(x_1^2 + x_2^2 - 1) - x_1 \quad \text{s.t.} \quad h = x_1^2 + x_2^2 - 1 = 0. \tag{23.40}$$

解是 $\boldsymbol{x}^\star = (1, 0)^\top$，在此处驻定条件 $(3, 0)^\top + \nu(2, 0)^\top = \boldsymbol{0}$ 给出 $\nu^\star = -3/2$。取 $\nu = \nu^\star$，于是 $\boldsymbol{B} = (4 + 2\nu)\boldsymbol{I} = \boldsymbol{I}$。

取圆上的点 $\boldsymbol{x} = (0.8, 0.6)^\top$，此时 $h = 0$，$f = -0.8$，梯度和 Jacobian 是

$$\nabla f = (2.2,\ 2.4)^\top, \qquad \boldsymbol{A} = (1.6,\ 1.2).$$

解 KKT 系统。用 $\boldsymbol{A}$ 左乘第一行并用 $\boldsymbol{A}\boldsymbol{d} = 0$，由 $\boldsymbol{A}\nabla f = 6.4$ 和 $\boldsymbol{A}\boldsymbol{A}^\top = 4$ 得 $\hat{\nu} = -1.6$，于是

$$\boldsymbol{d} = (0.36,\ -0.48)^\top, \qquad \boldsymbol{x} + \boldsymbol{d} = (1.16,\ 0.12)^\top.$$

这一步很好：到解的距离从 0.632 缩短到 0.2。可是真实函数值都变差了：

$$f(\boldsymbol{x}+\boldsymbol{d}) = -0.44 > -0.8, \qquad h(\boldsymbol{x}+\boldsymbol{d}) = 0.36 > 0.$$

目标上升，违反量也上升，对任何 $\rho > 0$，ϕ_ρ 都升高了，这一步被拒绝。过滤器同样拒绝，因为记录 $(0, -0.8)$ 在两个指标上都压过候选 $(0.36, -0.44)$。这种现象称为Maratos 效应（Maratos effect）：全步本可带来快速的局部收敛，却被接受规则判为失败，迫使算法缩短步长，收敛变慢。

原因在于约束的弯曲。线性化保证 $\boldsymbol{A}\boldsymbol{d} = -\boldsymbol{h}$，但二阶项留在了约束上，$h(\boldsymbol{x}+\boldsymbol{d}) = \|\boldsymbol{d}\|_2^2 = 0.36$。这个二阶大小的违反，足以抵消模型预期的目标下降。Lagrange 函数其实是下降的，目标的增量 0.36 加上 $\nu^\star$ 乘约束的增量 0.36，合计是 -0.18。评价函数中 ℓ_1 项的绝对值把这一点丢掉了。

补一个修正步 既然问题是二阶的违反，就补一步把它修掉。在 $\boldsymbol{x}+\boldsymbol{d}$ 处重新计算约束的值，但沿用当前的 Jacobian，求一个最小范数的修正：

$$\hat{\boldsymbol{d}} = -\boldsymbol{A}^{\top}\left(\boldsymbol{A}\boldsymbol{A}^{\top}\right)^{-1}\boldsymbol{h}(\boldsymbol{x}+\boldsymbol{d}). \tag{23.41}$$

然后用 $\boldsymbol{x}+\boldsymbol{d}+\hat{\boldsymbol{d}}$ 作候选点，这称为二阶修正（second-order correction）。

例中 $\boldsymbol{A}\boldsymbol{A}^{\top} = 4$，$h(\boldsymbol{x}+\boldsymbol{d}) = 0.36$，代入式 (23.41)，得

$$\hat{\boldsymbol{d}} = -(1.6,\ 1.2)^{\top} \times 0.09 = (-0.144,\ -0.108)^{\top}.$$

修正后的候选点及其函数值是

$$\boldsymbol{x}+\boldsymbol{d}+\hat{\boldsymbol{d}} = (1.016,\ 0.012)^{\top}, \quad h = 0.0324, \quad f = -0.9512.$$

现在 $\rho = 2$ 时评价函数的值是 $-0.9512 + 0.0648 = -0.8864$，低于 -0.8，步被接受，到解的距离只有 0.02。过滤器也接受它，因为目标已满足 $-0.9512 \le -0.8$。图 23.22(a) 是这两段，(b) 是整个迭代的比较。

23.1 局部二次模型
23.2 等式 QP 的求解
23.3 有效集法（Active-Set）
23.4 曲率的处理
23.5 更新的接受
23.6 模型的修复
23.7 收敛与计算成本
23.8 本章小结

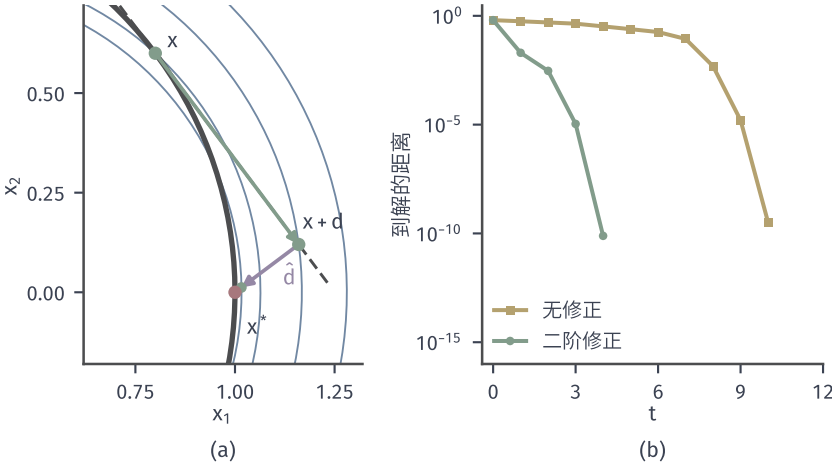


图 23.22 问题 (23.40)上的 Maratos 效应与二阶修正。(a) 深灰粗线是约束，蓝线是目标的等高线，虚线是线性化约束；绿色箭头是 QP 步，紫色箭头是修正步 $\hat{\boldsymbol{d}}$，红点是解。(b) $\rho = 2$、$\eta = 0.1$ 的回溯 SQP：不修正（黄）前七轮步长被缩短，修正（绿）后每轮都走全步。

为什么修正是二阶的 设 $\|\boldsymbol{d}\|_2$ 很小。约束在 $\boldsymbol{x}+\boldsymbol{d}$ 处的值只剩二阶项，所以 $\hat{\boldsymbol{d}}$ 的长度是 $\|\boldsymbol{d}\|_2^2$ 的量级，比主步小一阶，不会破坏主步带来的快速收敛。

把修正后的点代入约束展开，$\boldsymbol{A}(\boldsymbol{x}+\boldsymbol{d})$ 与 $\boldsymbol{A}(\boldsymbol{x})$ 之差是 $\|\boldsymbol{d}\|_2$ 的量级，乘以 $\hat{\boldsymbol{d}}$ 得三阶项；其余项也是三阶以上，因此修正后的违反量降到 $\|\boldsymbol{d}\|_2^3$ 的量级。

与重新解 QP 的区别 修正步用的是已有的 $\boldsymbol{A}$ 和它的分解，只换了右端，代价是一次回代加一次约束求值。重新构造并求解 QP 则要重新求导和分解。有不等式时，修正要在主步的工作集上做，或者把线性化约束的常数项换成 $\boldsymbol{g}(\boldsymbol{x}+\boldsymbol{d}) - \boldsymbol{G}\boldsymbol{d}$ 再解一次 QP，后者花费更多，但结果仍是原 QP 的一次扰动。

实现中通常只在全步被拒绝、且约束违反确实增加时才试一次修正，试探失败就回到回溯。也有别的办法绕开 Maratos 效应，例如暂时放行一步、几步之后再回头检查的非单调策略，以及改用可微的评价函数。

23.7 收敛与计算成本

各个部件都有了，本节回答三个问题：在解附近能收敛多快，什么时候算结束，以及每一轮的计算花在哪里。

精确 Hessian 的局部二次收敛 先看只含等式的情形，记 $\boldsymbol{w} = (\boldsymbol{x}, \boldsymbol{\nu})$。定理 23.4说全步长 SQP 就是 $\boldsymbol{F}(\boldsymbol{w}) = \boldsymbol{0}$ 上的 Newton 法，其 Jacobian 正是

KKT 矩阵 $\boldsymbol{K}(\boldsymbol{w})$。所以收敛性的证明与第 7章的证明思路相同，只是矩阵不再对称正定。

定理 23.10　SQP 的局部二次收敛　设 $\boldsymbol{w}^\star = (\boldsymbol{x}^\star, \boldsymbol{\nu}^\star)$ 满足等式约束问题的 KKT 条件，$\boldsymbol{A}(\boldsymbol{x}^\star)$ 行满秩，并且 $\nabla^2_{\boldsymbol{xx}}\mathcal{L}(\boldsymbol{w}^\star)$ 在 $\boldsymbol{A}(\boldsymbol{x}^\star)$ 的零空间上正定。设在半径为 r 的球内 $\boldsymbol{K}$ 满足

$$\|\boldsymbol{K}(\boldsymbol{w}) - \boldsymbol{K}(\boldsymbol{w}')\|_2 \le M\|\boldsymbol{w} - \boldsymbol{w}'\|_2. \tag{23.42}$$

令 $\sigma > 0$ 为 $\boldsymbol{K}(\boldsymbol{w}^\star)$ 的最小奇异值。若 $\|\boldsymbol{w}^{(t)} - \boldsymbol{w}^\star\|_2 < \min\{r, \sigma/(2M)\}$，则全步长 SQP 的下一点有定义，且

$$\|\boldsymbol{w}^{(t+1)} - \boldsymbol{w}^\star\|_2 \le \frac{M}{\sigma}\|\boldsymbol{w}^{(t)} - \boldsymbol{w}^\star\|_2^2. \tag{23.43}$$

证明　记 $\boldsymbol{e} = \boldsymbol{w}^{(t)} - \boldsymbol{w}^\star$，$\boldsymbol{K} = \boldsymbol{K}(\boldsymbol{w}^{(t)})$。定理 23.3说明 $\boldsymbol{K}(\boldsymbol{w}^\star)$ 可逆，所以 $\sigma > 0$。

第一步说明 $\boldsymbol{K}$ 的逆有界。由式 (23.42)，

$$\|\boldsymbol{K} - \boldsymbol{K}(\boldsymbol{w}^\star)\|_2 \le M\|\boldsymbol{e}\|_2 \le \frac{\sigma}{2}.$$

最小奇异值的扰动不超过矩阵差的范数，所以 $\boldsymbol{K}$ 的最小奇异值至少是 $\sigma/2$，即

$$\|\boldsymbol{K}^{-1}\|_2 \le \frac{2}{\sigma}.$$

第二步写出误差递推。由 $\boldsymbol{F}(\boldsymbol{w}^\star) = \boldsymbol{0}$ 沿线段积分，

$$\boldsymbol{F}(\boldsymbol{w}^{(t)}) = \int_0^1 \boldsymbol{K}(\boldsymbol{w}^\star + s\boldsymbol{e})\boldsymbol{e}\,\mathrm{d}s.$$

下一点是 $\boldsymbol{w}^{(t)}$ 减去 $\boldsymbol{K}^{-1}\boldsymbol{F}(\boldsymbol{w}^{(t)})$，把上式代入，得到

$$\boldsymbol{w}^{(t+1)} - \boldsymbol{w}^\star = \boldsymbol{K}^{-1}\int_0^1 \big(\boldsymbol{K} - \boldsymbol{K}(\boldsymbol{w}^\star + s\boldsymbol{e})\big)\boldsymbol{e}\,\mathrm{d}s.$$

第三步估计积分。由式 (23.42)，被积函数的范数不超过 $M(1-s)\|\boldsymbol{e}\|_2^2$，积分后得

$$\left\|\int_0^1 \big(\boldsymbol{K} - \boldsymbol{K}(\boldsymbol{w}^\star + s\boldsymbol{e})\big)\boldsymbol{e}\,\mathrm{d}s\right\|_2 \le \frac{M}{2}\|\boldsymbol{e}\|_2^2.$$

再乘以第一步的界，式 (23.43)成立。 ∎

这里 M 是 $\boldsymbol{K}$ 的 Lipschitz 常数，它由 f 与 h_j 的三阶导数大小和乘子的大小共同决定，当目标和约束的 Hessian 都 Lipschitz 连续时存在。由于 $\|\boldsymbol{e}\|_2 < \sigma/(2M)$ 时式 (23.43)的右端小于 $\|\boldsymbol{e}\|_2/2$，迭代留在球内，二次收敛一直保持。

条件各有用处。行满秩和约化曲率正定都是用来保证 $\boldsymbol{K}(\boldsymbol{w}^\star)$ 可逆的，这正是定理 23.3的条件。注意结论是关于 $\boldsymbol{w}$ 的。单看 $\boldsymbol{x}$ 的误差，或单看违反量，不必单调下降，表 23.2中 $t=1$ 到 $t=2$ 的 $|h|$ 就几乎不动。

含不等式时 由定理 23.7，LICQ、严格互补和二阶充分条件下，靠近解时局部 QP 有一个活动集恰为 $\boldsymbol{S}^\star$ 的解。若求解器返回这个解，SQP 就和把 $\boldsymbol{S}^\star$ 当作等式的 SQP 完全一样，定理 23.10适用于这个等式问题，得到二次收敛。

这里有三个“若”，缺一不可：活动集已被识别，全步长被接受，并且 QP 求解器选中了这个解。第二点正是上一节二阶修正要保证的。

拟 Newton 的局部超线性收敛 用近似矩阵时，分析更细。在同样的约束资格和二阶充分条件下，若迭代已收敛于解、步长为 1，并且 $\boldsymbol{B}^{(t)}$ 有界，式 (23.30)是 $\boldsymbol{x}^{(t)}$ 超线性收敛的刻画。这个结论的证明要比较拟 Newton 步与精确 Newton 步的差，篇幅较长，读者可查阅专著[2]。

[2] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

条件不会自动成立。全空间的 BFGS 矩阵需要沿 $\boldsymbol{d}^{(t)}$ 的切向分量持续得到好的曲率信息，阻尼会使一部分更新偏离割线条件。已知的保证多是两步超线性这样较弱的形式，或者依赖额外的假设。图 23.16中尾部的快速下降是一次运行的现象，不能当作普遍定理。

远离解时 上面的结论都假定初始点已经足够接近解。远离解时依靠接受规则。对罚函数线搜索，常见的全局结论是：若迭代点留在紧集内，f, g_i, h_j 足够光滑，约束梯度在其上一致线性无关，$\boldsymbol{B}^{(t)}$ 一致有界且一致正定，ρ 最终固定下来，QP 都相容，则极限点是原问题的 KKT 点。证明要用到式 (23.33)给出的逐步下降以及回溯的步长下界，读者可查阅专著[3]。过滤器有相应的结论，需要它自己的一组假设。

[3] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

这种结论要求的条件不同于局部结论，得到的也只是 KKT 点，不是全局最优解，非凸问题上它可能收敛到鞍点甚至极大方向的驻点附近。图 23.23是问题 (23.1)从远处出发的运行。圆上还有另一个 KKT 点 $(-1,-1)^{\mathsf{T}}$，那是圆上目标的最大点，乘子 $\nu=-1/2$，起点 $(0.2,-1.6)^{\mathsf{T}}$ 在圆的下方。

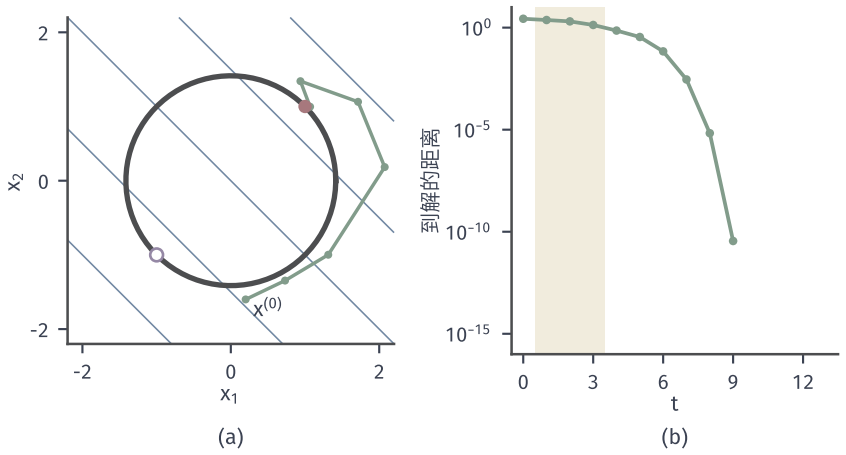


图 23.23 问题 (23.1)从 $(0.2,-1.6)^{\mathsf{T}}$、$\nu^{(0)}=1$ 出发的回溯 SQP，$\rho=1$，约化曲率不足 0.5 时移位。(a) 路径（绿）绕过圆的右侧到达解（红点），紫色空心点是圆上目标的最大点。(b) 到解的距离，黄色带是步长小于 1 的轮次，此后全步长二次收敛。

运行分成两个阶段。前四轮步长依次是 $1, 0.25, 0.5, 0.5$，其中第二到第五轮的约化曲率不足，加了移位，这是接受规则和曲率修正在起作用。之后步长一直是 1，到解的距离依次为 0.347、0.0686、0.00289、6.7×10^{-6}、3.5×10^{-11}，进入 Newton 的快速段。

停止准则 “QP 解完了”不是结束的标志，判断要回到原问题的 KKT 残差上。给定容差 $\varepsilon_{\mathrm{p}},\varepsilon_{\mathrm{d}},\varepsilon_{\mathrm{c}}>0$，同时检查原始可行、Lagrange 驻定和互补三项：

$$\begin{aligned} &\|\boldsymbol{h}(\boldsymbol{x})\|_\infty \le \varepsilon_{\mathrm{p}}, \qquad \|[\boldsymbol{g}(\boldsymbol{x})]_+\|_\infty \le \varepsilon_{\mathrm{p}}, \\ &\|\nabla f(\boldsymbol{x}) + \boldsymbol{A}^{\mathsf{T}}\boldsymbol{\nu} + \boldsymbol{G}^{\mathsf{T}}\boldsymbol{\lambda}\|_\infty \le \varepsilon_{\mathrm{d}}, \\ &\boldsymbol{\lambda} \ge \boldsymbol{0}, \qquad \max_i |\lambda_i g_i(\boldsymbol{x})| \le \varepsilon_{\mathrm{c}}. \end{aligned} \tag{23.44}$$

三项的单位不同，实际中要按目标与约束的尺度归一化。步长很小不能作为收敛的证据，那可能只是回溯失败。

一轮的成本 表 23.6按 n 个变量、$p+m$ 条约束的稠密情形列出一轮的主要开销。其中 QP 的迭代次数 k 在热启动的后期常常是 1 或很小的数，而在早期、活动集变动频繁时可能很大。

23.1 局部二次模型
23.2 等式 QP 的求解
23.3 有效集法（Active-Set）
23.4 曲率的处理
23.5 更新的接受
23.6 模型的修复
23.7 收敛与计算成本
23.8 本章小结

项目	开销
一阶导数	∇f 与 $\boldsymbol{A},\boldsymbol{G}$ 各一次
精确曲率	$m+p+1$ 个 Hessian 或 Hessian 向量积
拟 Newton 更新	约 $O(n^2)$
KKT 分解（等式）	约 $O((n+p)^3)$，稀疏时远小于此
工作集迭代	k 次，每次低秩修正约 $O(n^2)$
步的接受	每次试探 f 和约束各一次
二阶修正	约束一次，再加一次回代
恢复阶段	额外的模型构造与子问题求解

表 23.6 SQP 一轮的主要开销。

和第 22章的方法相比，SQP 每轮贵得多，一轮要解一个 QP，但轮数通常很少，适合函数求值昂贵、约束数目不太大的问题。约束和变量都很多、活动集又难以确定时，分解和工作集迭代的开销变大，第 24章的内点法每轮结构更固定，往往更合适。

23.8 本章小结

本章从圆周上的小问题出发，回答了章首提出的几个问题。SQP 在当前点把目标近似到二阶、把约束近似到一阶，得到一个局部 QP。目标的线性项来自 ∇f，曲率却要取 Lagrange 函数的 Hessian，因为约束的弯曲只有通过乘子才折算得进模型。所以算法同时维护原始变量和乘子。

只含等式时，局部 QP 归结为一个 KKT 线性系统，可以整体分解，也可以分成法向段和零空间内的切向段。行满秩和约化 Hessian 正定保证解是模型的最小点。取精确 Lagrange Hessian 时，这个系统正是原问题 KKT 方程的 Newton 步。

含不等式时要决定哪些约束算数。有效集法维护工作集，步非零时用比值检验防止越界，步为零时用乘子的符号决定释放哪条约束。有效集法只是 QP 的一种解法，并不是 SQP 的一部分，QP 也可以用内点法等方法求解。工作集属于当前的线性化 QP，只有在约束资格、二阶充分条件和严格互补下，靠近解时才与原问题的活动集一致。

曲率方面，KKT 矩阵可逆、约化 Hessian 正定、$\boldsymbol{B}$ 在全空间正定是三件不同的事。负曲率可以用移位、约化曲率修正或信赖域处理，它们分别改变模型或步长范围。拟 Newton 近似用同一组乘子下的 Lagrange 梯度差作割线，用阻尼保持正定，超线性收敛还需要沿步方向的切向曲率逐渐准确。

模型的步要放回原问题检验。罚函数把目标和违反量压成一个数，权重必须超过乘子，又不宜过大；过滤器并排比较两个指标，靠裕量、切换规则和恢复阶段才成为完整的机制。线性化约束无解时用弹性子问题或恢复

阶段修复子问题，好步被弯曲约束的二阶违规挡住时用二阶修正修复候选步。恢复失败也不能证明原问题不可行。

最后要分清两类结论。解附近的快速收敛依赖约束资格、二阶充分条件、活动集的识别和全步长的接受；远离解时的可靠进展依赖接受规则和一致有界的曲率。两者条件不同，结论也不同，后者只给出 KKT 点，并不给出全局最优。全程都要分别检查 QP 的可行性与原非线性约束的可行性，前者只是后者在切平面上的影子。

24.1 障碍问题
24.1.1 对数障碍
24.1.2 参数与路径
24.2 原始—对偶内点法
24.3 初始化与精度
24.4 锥规划中的障碍
24.5 保证与计算成本
24.6 本章小结

第 24 章

内点法

第 4章解线性规划时，从可行域内部沿中心路径走向最优解。那里的约束只是 $x_i \ge 0$，迭代点离每面墙有多远，看坐标就知道。现在换一个问题：在抛物线 $x_2 \ge x_1^2$ 与直线 $x_2 \le 4$ 围成的区域里，求离点 $(3,0)$ 最近的点。墙是弯的，走一步之后，点离墙有多远要重新计算约束函数才知道。

路径跟踪的骨架可以保留：在边界上立起障碍，放宽互补条件，用 Newton 法沿参数曲线前进。需要重新回答的问题集中在四处。约束的曲率会进入线性方程组，Newton 步可能不再是下降方向。严格内点不再一眼可见，乘子的符号也要专门维护。一个残差很小的点，未必满足原问题的最优性条件。更根本的是，线性规划有多项式时间的保证，一般光滑约束问题没有。

本章只讲这些新增的内容，线性规划里已经讲过的路径跟踪细节直接引用。第一节构造一般约束的障碍子问题，研究路径的存在性和间隙。第二节把松弛变量和乘子纳入同一组方程，推导 Newton 方向，并讨论步长的接受。第三节回答起点从哪里来、什么时候可以停。第四节把障碍换成二阶锥和半正定锥的形式。第五节说明哪些结论是全局证书，哪些只是局部结果，并计算每一轮的代价。

24.1 障碍问题

约束是一般的光滑函数时，怎样把“不许越界”写进目标，又让解最终能落到边界上？做法是求解一族带参数的内点子问题，再逐步减小参数。

问题与贯穿例　本章讨论光滑约束问题

$$\min_{\boldsymbol{x}\in\mathbb{R}^n} \; f(\boldsymbol{x}) \quad \text{s.t.} \quad g_i(\boldsymbol{x}) \le 0\,(i=1,\dots,m), \quad h_j(\boldsymbol{x}) = 0\,(j=1,\dots,p), \tag{24.1}$$

其中 f、g_i、h_j 二阶连续可微。把约束值排成向量 $\boldsymbol{g}(\boldsymbol{x})$、$\boldsymbol{h}(\boldsymbol{x})$，把它们的梯度按行排成两个 Jacobian 矩阵：

$$\boldsymbol{J}(\boldsymbol{x}) = \begin{bmatrix} \nabla g_1(\boldsymbol{x})^{\top} \\ \vdots \\ \nabla g_m(\boldsymbol{x})^{\top} \end{bmatrix} \in \mathbb{R}^{m\times n}, \qquad \boldsymbol{A}(\boldsymbol{x}) = \begin{bmatrix} \nabla h_1(\boldsymbol{x})^{\top} \\ \vdots \\ \nabla h_p(\boldsymbol{x})^{\top} \end{bmatrix} \in \mathbb{R}^{p\times n}. \tag{24.2}$$

本章的 $\boldsymbol{g}$ 始终表示约束值，不表示目标的梯度；目标梯度写成 ∇f。

全章贯穿下面这个二维例子：

$$\begin{aligned} \min_{\boldsymbol{x}} \quad & f(\boldsymbol{x}) = \tfrac{1}{2}\big((x_1-3)^2 + x_2^2\big) \\ \text{s.t.} \quad & g_1(\boldsymbol{x}) = x_1^2 - x_2 \le 0, \\ & g_2(\boldsymbol{x}) = x_2 - 4 \le 0. \end{aligned} \tag{24.3}$$

可行集是抛物线之上、直线 $x_2 = 4$ 之下的区域，目标是到点 $\boldsymbol{c} = (3,0)^{\top}$ 的距离平方的一半。g_1 是弯的约束，g_2 是线性约束。

第 17章的 KKT 条件用到 Lagrange 函数

$$\mathcal{L}(\boldsymbol{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}) = f(\boldsymbol{x}) + \boldsymbol{\lambda}^{\top}\boldsymbol{g}(\boldsymbol{x}) + \boldsymbol{\nu}^{\top}\boldsymbol{h}(\boldsymbol{x}). \tag{24.4}$$

条件是说：可行点 $\boldsymbol{x}^{\star}$ 处存在乘子 $\boldsymbol{\lambda}^{\star} \ge \boldsymbol{0}$ 和 $\boldsymbol{\nu}^{\star}$，使 $\mathcal{L}$ 对 $\boldsymbol{x}$ 的梯度为零，并且 $\lambda_i^{\star} g_i(\boldsymbol{x}^{\star}) = 0$。

例 (24.3)中取 $\boldsymbol{x}^{\star} = (1,1)^{\top}$，这时两个约束值和三个梯度是

$$g_1 = 0, \quad g_2 = -3, \quad \nabla f = \begin{bmatrix} -2 \\ 1 \end{bmatrix}, \quad \nabla g_1 = \begin{bmatrix} 2 \\ -1 \end{bmatrix}, \quad \nabla g_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

于是 $\boldsymbol{\lambda}^{\star} = (1,0)^{\top}$ 满足全部 KKT 条件，最优值 $f^{\star} = 5/2$。问题是凸的，$\boldsymbol{x}^{\star}$ 就是全局解。图 24.1画出了这一几何关系。

24.1 障碍问题
24.1.1 对数障碍
24.1.2 参数与路径
24.2 原始—对偶内点法
24.3 初始化与精度
24.4 锥规划中的障碍
24.5 保证与计算成本
24.6 本章小结

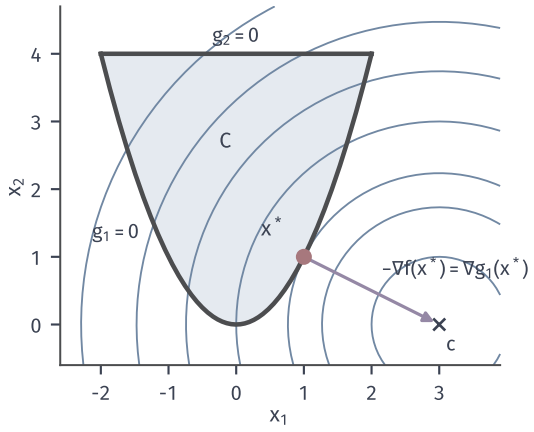


图 24.1 贯穿例 (24.3)。浅蓝区域是可行集 $\boldsymbol{C}$，深灰粗线是两段边界，蓝线是目标的等值线（以黑叉 $\boldsymbol{c}=(3,0)$ 为圆心的圆），红点是最优解 $\boldsymbol{x}^\star=(1,1)$。紫色箭头同时是 $-\nabla f(\boldsymbol{x}^\star)$ 和 $\nabla g_1(\boldsymbol{x}^\star)$，两者相等对应乘子 $\lambda_1^\star=1$；直线边界不活动，乘子为零。

内部只对不等式而言 障碍只能加给不等式，因为只有不等式才有“里面”。记严格可行点的集合为

$$\boldsymbol{C}^\circ=\{\boldsymbol{x}:g_i(\boldsymbol{x})<0\,(i=1,\dots,m),\ \boldsymbol{h}(\boldsymbol{x})=\boldsymbol{0}\}. \tag{24.5}$$

等式约束的可行点构成一张薄片，薄片上没有“离边界远一点”的余地。把 $h=0$ 拆成 $h\le 0$ 和 $-h\le 0$ 也行不通，这两条不等式不可能同时严格成立，拆完之后 $\boldsymbol{C}^\circ$ 是空集。所以等式约束继续显式保留，加上障碍之后的问题仍然是约束问题，而不是无约束问题。

24.1.1 对数障碍

第 4章对 $x_i\ge 0$ 用的障碍是 $-\log x_i$。约束 $x_i\ge 0$ 也可以写成 $g_i(\boldsymbol{x})=-x_i\le 0$，于是 $-\log x_i=-\log(-g_i(\boldsymbol{x}))$。这个写法可以直接推广到任何 g_i。

定义 24.1 对数障碍函数 设 $\boldsymbol{C}^\circ$ 非空。对 $\mu>0$，$\boldsymbol{g}(\boldsymbol{x})<\boldsymbol{0}$ 的点上定义

$$\phi(\boldsymbol{x})=-\sum_{i=1}^{m}\log\bigl(-g_i(\boldsymbol{x})\bigr),\qquad B_\mu(\boldsymbol{x})=f(\boldsymbol{x})+\mu\,\phi(\boldsymbol{x}). \tag{24.6}$$

相应的**障碍子问题**（barrier subproblem）是

$$\min_{\boldsymbol{x}}\ B_\mu(\boldsymbol{x})\quad\text{s.t.}\quad \boldsymbol{h}(\boldsymbol{x})=\boldsymbol{0},\quad \boldsymbol{g}(\boldsymbol{x})<\boldsymbol{0}. \tag{24.7}$$

点靠近某条约束的边界时，$-g_i \downarrow 0$，$\phi \to +\infty$。边界像一堵墙，迭代点靠函数值的上升留在内部。例 (24.3)的障碍目标是

$$B_\mu(\boldsymbol{x}) = \tfrac{1}{2}\big((x_1-3)^2 + x_2^2\big) - \mu\log(x_2 - x_1^2) - \mu\log(4 - x_2).$$

图 24.2画出两个参数下的等值线。参数较大时碗底靠近区域中央，参数较小时等值线贴向边界，碗底被目标拉向 $\boldsymbol{x}^\star$。

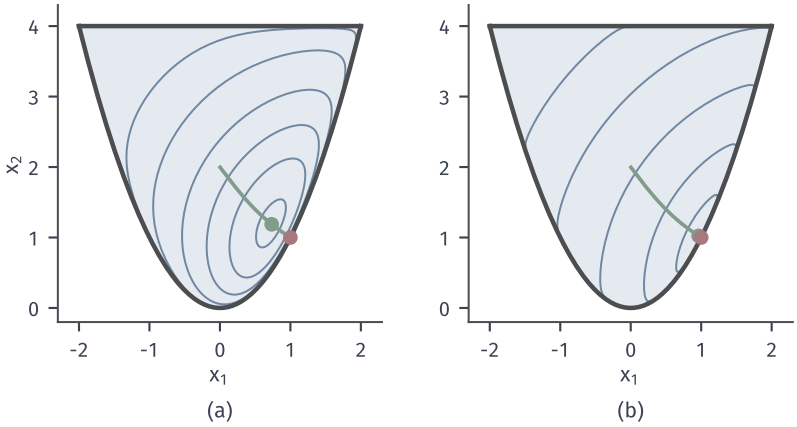


图 24.2　贯穿例的障碍目标 B_μ 在可行集内的等值线（蓝线）。(a)$\mu = 1$；(b)$\mu = 0.1$。绿线是各参数下碗底连成的曲线，绿点是当前参数的碗底，红点是 $\boldsymbol{x}^\star$。

约束的梯度和 Hessian 怎样进入　求导只需要复合函数法则。对一元函数 $\psi(u) = -\log(-u)$（$u < 0$），有

$$\psi'(u) = \frac{1}{-u}, \qquad \psi''(u) = \frac{1}{u^2}.$$

把 $u = g_i(\boldsymbol{x})$ 代入，并对 i 求和，得到障碍函数的梯度和 Hessian：

$$\nabla\phi(\boldsymbol{x}) = \sum_{i=1}^{m} \frac{1}{-g_i(\boldsymbol{x})}\,\nabla g_i(\boldsymbol{x}), \tag{24.8}$$

$$\nabla^2\phi(\boldsymbol{x}) = \sum_{i=1}^{m} \frac{\nabla g_i(\boldsymbol{x})\nabla g_i(\boldsymbol{x})^{\mathsf{T}}}{g_i(\boldsymbol{x})^2} + \sum_{i=1}^{m} \frac{\nabla^2 g_i(\boldsymbol{x})}{-g_i(\boldsymbol{x})}. \tag{24.9}$$

式 (24.9)的两项作用不同。第一项是秩一矩阵之和，只在约束的法向产生曲率，点越靠近边界越大，这就是“墙”的刚度。第二项把约束本身的弯曲带进来，线性规划中 $\nabla^2 g_i = \mathbf{0}$，这一项不存在，所以它正是本章新增的内容。

在贯穿例的点 $\boldsymbol{x} = (1,2)^{\mathsf{T}}$ 上算一次。约束值与约束梯度是

$$g_1 = -1, \quad g_2 = -2, \quad \nabla g_1 = \begin{bmatrix} 2 \\ -1 \end{bmatrix}, \quad \nabla g_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad \nabla^2 g_1 = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}.$$

代入式 (24.8)，得到

$$\nabla\phi = 1\cdot\begin{bmatrix}2\\-1\end{bmatrix} + \frac{1}{2}\begin{bmatrix}0\\1\end{bmatrix} = \begin{bmatrix}2\\-1/2\end{bmatrix}.$$

代入式 (24.9)，三块矩阵相加：

$$\nabla^2\phi = \begin{bmatrix}4 & -2\\-2 & 1\end{bmatrix} + \begin{bmatrix}0 & 0\\0 & 1/4\end{bmatrix} + \begin{bmatrix}2 & 0\\0 & 0\end{bmatrix} = \begin{bmatrix}6 & -2\\-2 & 5/4\end{bmatrix}.$$

最后一块 $\mathrm{diag}(2,0)$ 来自抛物线的弯曲，如果把 g_1 换成切线，它就消失了。

一维边界例子：内点步受到的限制　Newton 法用二次模型近似 B_μ，而障碍函数在边界附近根本不像二次函数。看最简单的弯约束：

$$\min_{x}\; x \quad \text{s.t.} \quad x^2 - 1 \le 0.$$

解是 $x^\star = -1$。障碍目标 $B_\mu(x) = x - \mu\log(1-x^2)$ 的导数是

$$B'_\mu(x) = 1 + \frac{2\mu x}{1-x^2}, \qquad B''_\mu(x) = \frac{2\mu(1+x^2)}{(1-x^2)^2}.$$

令 $B'_\mu(x)=0$，得到 $1 - x^2 + 2\mu x = 0$。在 $(-1,1)$ 内的根是

$$x(\mu) = \mu - \sqrt{\mu^2+1}. \tag{24.10}$$

取几个能算成分数的值：$\mu = 3/4$ 时 $x=-1/2$，$\mu = 5/12$ 时 $x=-2/3$。

现在站在 $\mu = 3/4$ 的碗底 $x=-1/2$，把参数减小到 μ^+，走一个 Newton 步。在这一点上

$$\frac{2x}{1-x^2} = -\frac{4}{3}, \qquad \frac{2(1+x^2)}{(1-x^2)^2} = \frac{40}{9}.$$

于是 Newton 步是

$$d = -\frac{1 - \frac{4}{3}\mu^+}{\frac{40}{9}\mu^+} = -\frac{9 - 12\mu^+}{40\mu^+}.$$

$\mu^+ = 5/12$ 时 $d = -6/25$，新点 -0.74 仍在区间内，离新的碗底 $-2/3$ 不远。$\mu^+ = 0.05$ 时 $d = -4.2$，新点是 -4.7，已经远在可行域之外，如图 24.3(b) 所示。要让单位步留在区间内，需要 $d > -1/2$，解这个不等式，得到

$$\mu^+ > \frac{9}{32}.$$

也就是说，这一点上参数最多缩小到原来的 3/8。参数一次减得太多，碗底搬走了，二次模型却还停留在旧的位置。

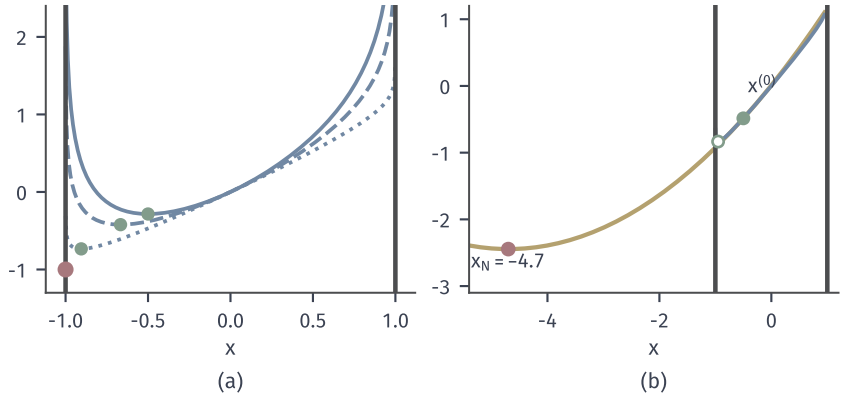


图 24.3 一维边界例子 $\min x$，$x^2 \le 1$。(a) 蓝线是 B_μ，实线、虚线、点线分别对应 $\mu = 3/4$、$5/12$、0.1，绿点是碗底，红点是解 $x^\star = -1$，深灰粗线是边界 $x = \pm 1$。(b) 参数减到 $\mu^+ = 0.05$，蓝线是 B_{μ^+}，只在区间内有定义；黄线是在绿点 $x^{(0)} = -1/2$ 处的二次模型，其极小点（红点）落在 -4.7；空心绿点是新的碗底。

新的曲率与凸性 约束的弯曲方向决定第二项的符号。g_i 凸时 $\nabla^2 g_i \succeq \mathbf{0}$，第二项半正定，障碍函数保持凸性。

> **引理 24.2 凸约束的障碍是凸函数** 设每个 g_i 在开集上凸且二阶连续可微，则 ϕ 在集合 $\{\boldsymbol{x} : \boldsymbol{g}(\boldsymbol{x}) < \mathbf{0}\}$ 的每个凸子集上是凸函数。

> **证明** 式 (24.9)中，第一项是半正定矩阵的非负组合。第二项中 $-g_i > 0$，$\nabla^2 g_i \succeq \mathbf{0}$，也是半正定矩阵的非负组合。所以 $\nabla^2 \phi \succeq \mathbf{0}$。 ■

g_i 非凸时，这个结论没有理由成立，用了对数也不会自动得到凸子问题。看单位圆盘的外部，约束是 $g(\boldsymbol{x}) = 1 - \|\boldsymbol{x}\|_2^2 \le 0$。这时 $\nabla^2 g = -2\boldsymbol{I}$，式 (24.9)给出

$$\nabla^2 \phi(\boldsymbol{x}) = \frac{4\boldsymbol{x}\boldsymbol{x}^\top}{(\|\boldsymbol{x}\|_2^2 - 1)^2} - \frac{2\boldsymbol{I}}{\|\boldsymbol{x}\|_2^2 - 1}.$$

沿与 $\boldsymbol{x}$ 垂直的切向，第一项为零，第二项是负的，曲率等于 $-2/(\|\boldsymbol{x}\|_2^2 - 1)$，离边界越近越负。

图 24.4取目标 $x_2^2 + 0.12(x_1 - 1/2)^2$，并取 $\mu = 0.1$。障碍目标有两个彼此隔开的局部极小点，分别在圆盘的右侧和左侧。图 (b) 沿点 $(1.5, 0)$ 处的切向对比两种约束：外部约束的障碍在这一点是山顶形状，圆盘内部约束的障碍则是碗。

24.1 障碍问题
24.1.1 对数障碍
24.1.2 参数与路径
24.2 原始—对偶内点法
24.3 初始化与精度
24.4 锥规划中的障碍
24.5 保证与计算成本
24.6 本章小结

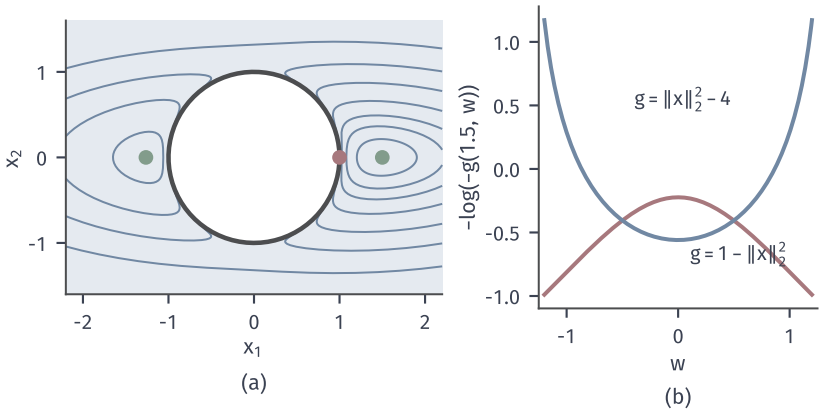


图 24.4 非凸约束的障碍。(a) 可行集是单位圆盘的外部（浅蓝），蓝线是 $B_{0.1}$ 的等值线，两个绿点是障碍目标的局部极小点，红点是原问题的全局解 $(1,0)$。(b) 沿 $x_1 = 1.5$ 的切向，红线是外部约束 $g = 1 - \|\boldsymbol{x}\|_2^2$ 的障碍，在 $w = 0$ 处曲率为负；蓝线是圆盘内部约束 $g = \|\boldsymbol{x}\|_2^2 - 4$ 的障碍，曲率为正。

24.1.2 参数与路径

固定一个 μ，子问题 (24.7)有没有解？解随 μ 怎样变？这一小节先用驻定条件把子问题和 KKT 条件联系起来，再分凸问题和非凸问题回答这两个问题。

驻定条件就是扰动的互补 子问题 (24.7)的一阶条件是：存在 $\boldsymbol{\nu}$，使

$$\nabla B_\mu(\boldsymbol{x}) + \boldsymbol{A}(\boldsymbol{x})^\top \boldsymbol{\nu} = \boldsymbol{0}.$$

把式 (24.8)代入，得到

$$\nabla f(\boldsymbol{x}) + \sum_{i=1}^{m} \frac{\mu}{-g_i(\boldsymbol{x})} \nabla g_i(\boldsymbol{x}) + \boldsymbol{A}(\boldsymbol{x})^\top \boldsymbol{\nu} = \boldsymbol{0}.$$

求和中的系数都是正数，并且正好处在 KKT 条件中乘子的位置。令 $\lambda_i = \mu/(-g_i(\boldsymbol{x}))$，条件变成

$$\begin{aligned} &\nabla f(\boldsymbol{x}) + \boldsymbol{J}(\boldsymbol{x})^\top \boldsymbol{\lambda} + \boldsymbol{A}(\boldsymbol{x})^\top \boldsymbol{\nu} = \boldsymbol{0}, \qquad \boldsymbol{h}(\boldsymbol{x}) = \boldsymbol{0}, \\ &\lambda_i\big(-g_i(\boldsymbol{x})\big) = \mu \ (i = 1, \dots, m), \qquad \boldsymbol{g}(\boldsymbol{x}) < \boldsymbol{0}, \quad \boldsymbol{\lambda} > \boldsymbol{0}. \end{aligned} \tag{24.11}$$

与 KKT 条件逐项比较，只有互补一处不同：$\lambda_i g_i = 0$ 换成了 $\lambda_i(-g_i) = \mu$。这和第 4章的 $x_i s_i = \mu$ 是同一件事。乘子不是另外猜出来的，它就是障碍项在该约束上施加的推力，$\lambda_i = \mu/(-g_i)$ 离墙越近越大。

子问题的解何时存在 碗底的存在要靠水平集被围住。下面的定理说明，可行集有界时墙就足够了。

定理 24.3 障碍子问题的解 设 f、g_i、h_j 连续，可行集 $\boldsymbol{C}$ 有界，$\boldsymbol{C}^\circ$ 非空，$\mu > 0$。则 B_μ 在 $\boldsymbol{C}^\circ$ 上取到最小值。

再设 f、g_i 凸且二阶连续可微，$\boldsymbol{h}(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}$，$\boldsymbol{A}$ 满行秩，并且不存在非零的 $\boldsymbol{d}$ 同时满足

$$\boldsymbol{A}\boldsymbol{d} = \boldsymbol{0}, \quad \boldsymbol{d}^{\top}\nabla^2 f\,\boldsymbol{d} = 0, \quad \nabla g_i^{\top}\boldsymbol{d} = 0, \quad \boldsymbol{d}^{\top}\nabla^2 g_i\,\boldsymbol{d} = 0\ (\forall i) \tag{24.12}$$

（各导数在 $\boldsymbol{C}^\circ$ 的任一点取值）。则最小点 $\boldsymbol{x}(\mu)$ 唯一，方程组 (24.11)有唯一解 $(\boldsymbol{x}(\mu), \boldsymbol{\lambda}(\mu), \boldsymbol{\nu}(\mu))$。

证明 先证存在。$\boldsymbol{C}$ 是有界闭集，f 和每个 $-g_i$ 在其上连续，所以存在常数 F 和 $G > 1$，使 $|f| \le F$，$-g_i \le G$。

取 $\boldsymbol{x}^{(0)} \in \boldsymbol{C}^\circ$，考虑下水平集

$$\{\boldsymbol{x} \in \boldsymbol{C}^\circ : B_\mu(\boldsymbol{x}) \le B_\mu(\boldsymbol{x}^{(0)})\}.$$

对其中的点和任一下标 i，把其余各项移到右边，得到

$$-\mu \log\bigl(-g_i(\boldsymbol{x})\bigr) \le B_\mu(\boldsymbol{x}^{(0)}) + F + \mu(m-1)\log G.$$

右端是常数，所以存在 $\epsilon > 0$，使 $-g_i(\boldsymbol{x}) \ge \epsilon$。这说明水平集是 $\boldsymbol{C}$ 的闭子集，从而是紧集，连续函数 B_μ 在其上取到最小值。

再证唯一。由引理 24.2, B_μ 凸。对满足 $\boldsymbol{A}\boldsymbol{d} = \boldsymbol{0}$ 的非零 $\boldsymbol{d}$, 式 (24.9)给出

$$\boldsymbol{d}^{\top}\nabla^2 B_\mu \boldsymbol{d} = \boldsymbol{d}^{\top}\nabla^2 f\,\boldsymbol{d} + \mu\sum_{i=1}^{m}\Bigl(\frac{(\nabla g_i^{\top}\boldsymbol{d})^2}{g_i^2} + \frac{\boldsymbol{d}^{\top}\nabla^2 g_i\,\boldsymbol{d}}{-g_i}\Bigr).$$

右端各项非负，由条件 (24.12)，它们不全为零，所以 B_μ 在仿射集上严格凸，最小点唯一。

最后看方程组。最小点处梯度与 $\boldsymbol{A}$ 的零空间正交，所以存在 $\boldsymbol{\nu}$ 使驻定条件成立，$\boldsymbol{A}$ 满行秩使 $\boldsymbol{\nu}$ 唯一，$\boldsymbol{\lambda}$ 由 $\lambda_i = \mu/(-g_i)$ 确定。反过来，方程组的解满足凸函数 B_μ 在仿射集上的一阶条件，因此就是最小点。 ■

存在性的第一部分没有用到凸性，它只用到有界和连续。可行集无界时，这个结论可能失败。问题 $\min 0$、$-x \le 0$ 的最优解集是 $[0, \infty)$，障碍目标 $-\mu\log x$ 在 $x \to \infty$ 时趋于 $-\infty$，没有最小点。条件 (24.12)在贯穿例中成立，因为 $\nabla^2 f = \boldsymbol{I}$，第二项已经排除了所有非零方向。

路径　定理的条件成立时，μ 取遍 $(0,\infty)$，解连成一条曲线，沿用第 4章的名字，称为中心路径。图 24.5画出贯穿例的路径。当 $\mu\to\infty$ 时，目标的作用可以忽略，点趋于 ϕ 的最小点，即解析中心。贯穿例的解析中心可以直接求：对称性给出 $x_1=0$，再由 $-1/x_2+1/(4-x_2)=0$ 得到 $x_2=2$。

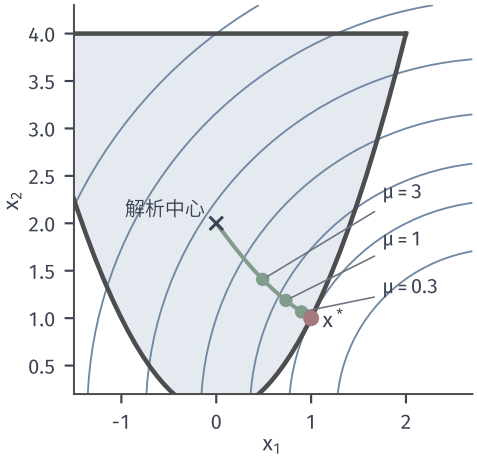


图 24.5　贯穿例的中心路径（绿线）。黑叉是解析中心 $(0,2)$，绿点是 $\mu=3$、1、0.3 对应的中心点，红点是 $\boldsymbol{x}^\star=(1,1)$，蓝线是目标的等值线。路径是弯的，因为不活动的直线约束的影响在逐渐消失。

这个例子的路径可以化成一元方程。由方程组 (24.11)的第一行，$\lambda_1=(3-x_1)/(2x_1)$。取 $\mu=1$，用 Newton 法解出的中心点和乘子是

$$\boldsymbol{x}(1)\approx(0.7343,1.1873)^{\mathsf{T}},\qquad \boldsymbol{\lambda}(1)\approx(1.5428,0.3555)^{\mathsf{T}}.$$

可以核对互补：$\lambda_1(x_2-x_1^2)=1.5428\times0.6481\approx1$，$\lambda_2(4-x_2)=0.3555\times2.8127\approx1$。

图 24.6(a) 显示乘子沿路径的走向。活动约束的乘子 $\lambda_1(\mu)$ 趋于 $\lambda_1^\star=1$，不活动约束的乘子 $\lambda_2(\mu)$ 按 $\mu/3$ 的量级趋于零，这里的 3 就是直线约束在解处的松弛。乘子估计本身就在告诉我们哪条约束活动，这一点不需要事先猜测。

凸问题的间隙　第 4章中，沿路径的对偶间隙恰好是 $n\mu$。一般凸问题也有同样的结果，只是 n 要换成不等式的条数 m。

定理 24.4　路径上的间隙　设 f、g_i 凸且可微，$\boldsymbol{h}(\boldsymbol{x})=\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}$，$(\boldsymbol{x},\boldsymbol{\lambda},\boldsymbol{\nu})$ 满足方程组 (24.11)，$f^\star$ 是问题 (24.1)在可行集上的下确界。则

$$f(\boldsymbol{x})-m\mu\le f^\star\le f(\boldsymbol{x}).\tag{24.13}$$

证明 右边的不等式成立是因为 $\boldsymbol{x}$ 可行。对左边，任取可行点 $\boldsymbol{x}'$。因为 $\boldsymbol{\lambda} > \mathbf{0}$、$\boldsymbol{g}(\boldsymbol{x}') \le \mathbf{0}$、$\boldsymbol{h}(\boldsymbol{x}') = \mathbf{0}$，有

$$f(\boldsymbol{x}') \ge f(\boldsymbol{x}') + \boldsymbol{\lambda}^{\top}\boldsymbol{g}(\boldsymbol{x}') + \boldsymbol{\nu}^{\top}\boldsymbol{h}(\boldsymbol{x}') = \mathcal{L}(\boldsymbol{x}', \boldsymbol{\lambda}, \boldsymbol{\nu}).$$

$\mathcal{L}(\cdot, \boldsymbol{\lambda}, \boldsymbol{\nu})$ 是凸函数，并且在 $\boldsymbol{x}$ 处梯度为零，所以 $\boldsymbol{x}$ 是它的全局最小点：

$$\mathcal{L}(\boldsymbol{x}', \boldsymbol{\lambda}, \boldsymbol{\nu}) \ge \mathcal{L}(\boldsymbol{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}).$$

再用 $\boldsymbol{h}(\boldsymbol{x}) = \mathbf{0}$ 和 $\lambda_i g_i(\boldsymbol{x}) = -\mu$，得到

$$\mathcal{L}(\boldsymbol{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}) = f(\boldsymbol{x}) + \sum_{i=1}^{m} \lambda_i g_i(\boldsymbol{x}) = f(\boldsymbol{x}) - m\mu.$$

三式相连，对 $\boldsymbol{x}'$ 取下确界即得。 ■

式 (24.13)的左端是一个对偶值，它由当前点直接算出，不需要知道 $\boldsymbol{x}^{\star}$。要保证目标误差不超过 ε，走到 $\mu \le \varepsilon/m$ 就够了。

这个界数的是全部 m 条约束，实际误差往往更小。图 24.6(b) 中，贯穿例的 $f(\boldsymbol{x}(\mu)) - f^{\star}$ 在 μ 小时约等于 μ，而不是 2μ。原因是不活动的约束虽然也贡献了 $\lambda_2 s_2 = \mu$，它却只是把对偶值往下拉，并不代表目标还有这么多可以下降。

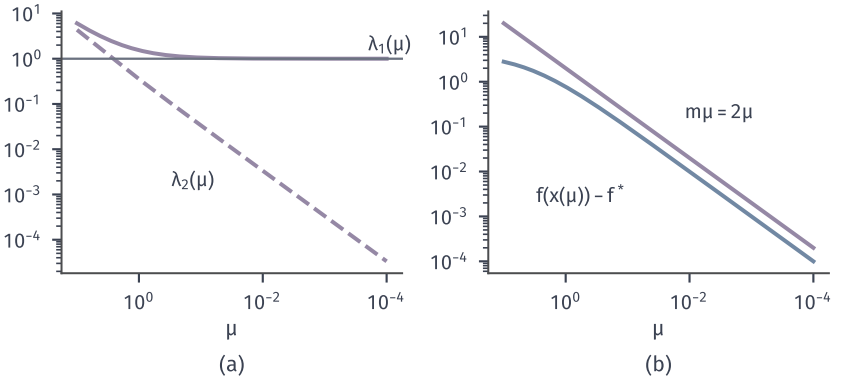


图 24.6 贯穿例沿中心路径的量，横轴是 μ，向右减小。(a) 紫色实线是 $\lambda_1(\mu)$，趋于 $\lambda_1^{\star} = 1$（灰线）；紫色虚线是 $\lambda_2(\mu)$，随 μ 线性趋于零。(b) 紫线是定理的界 $m\mu = 2\mu$，蓝线是实际误差 $f(\boldsymbol{x}(\mu)) - f^{\star}$。

固定参数时解多准，参数降多快 这样就得到**障碍法**（barrier method）：外层维护参数 μ，内层从上一个点出发，用第 7章的阻尼 Newton 法解子问题 (24.7)，解到 Newton 减量足够小，再令 $\mu \leftarrow \tau\mu$，其中 $\tau \in (0,1)$。回溯时要多加一条规则，试探点若使某个 $g_i \ge 0$，直接拒绝。

以贯穿例从 $\boldsymbol{x}^{(0)} = (1, 2)^{\top}$、$\mu = 1$ 开始。前面已经算出 $\nabla\phi$ 和 $\nabla^2\phi$，把目标的导数加上，得到

$$\nabla B_1 = \begin{bmatrix} 0 \\ 3/2 \end{bmatrix}, \qquad \nabla^2 B_1 = \begin{bmatrix} 7 & -2 \\ -2 & 9/4 \end{bmatrix}.$$

解线性方程组，Newton 方向是

$$\boldsymbol{d} = \left(-\frac{12}{47}, -\frac{42}{47}\right)^{\top} \approx (-0.2553,\ -0.8936)^{\top}.$$

单位步后的点 $(0.7447, 1.1064)^{\top}$ 仍然严格可行，再走两步就到达 $\boldsymbol{x}(1)$ 附近。

外层有两种取舍。τ 接近 1 时，上一个点几乎就是新碗底，每轮只需一两个 Newton 步，但要走很多轮。τ 很小时，轮数少，但正如一维例子所示，起步时 Newton 步很不可靠，每轮要靠回溯慢慢走。

图 24.7是贯穿例上的实测，从解析中心出发，要求 $m\mu \le 10^{-6}$。$\tau = 0.9$ 时总共要 218 个 Newton 步，$\tau = 0.5$ 时 38 步，$\tau = 0.1$ 时 32 步，$\tau = 0.001$ 时只要 18 步，单轮最多也不过 6 步。这说明 Newton 步的总数对 τ 不敏感，只有 τ 过于接近 1 时明显吃亏。

这是一个二维小例子上的观察，并且总数随 τ 并不单调。规模增大时，大幅度减小参数的代价一般会更明显，第 24.5节再谈理论上的界。

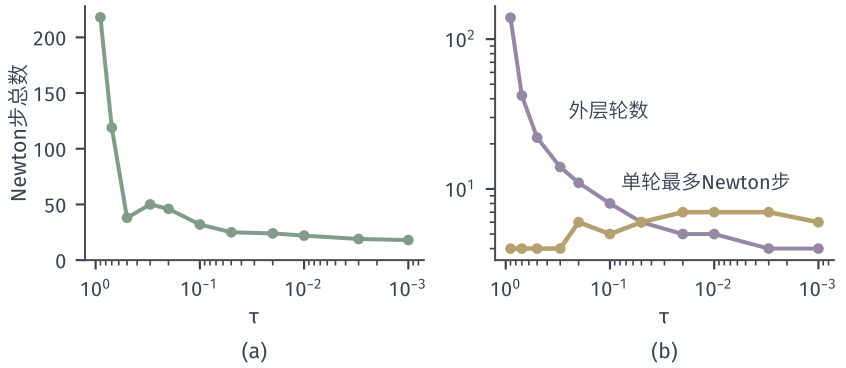


图 24.7　贯穿例上障碍法的工作量，$\mu^{(0)} = 1$，内层 Newton 减量阈值 10^{-8}，横轴是参数缩小倍率 τ，向右更激进。(a)Newton 步总数。(b) 紫线是外层轮数，黄线是单轮最多的 Newton 步数。

非凸问题只能谈局部路径　没有凸性时，定理 24.4的推理在“$\boldsymbol{x}$ 是 $\mathcal{L}$ 的全局最小点”这一步断掉，方程组 (24.11)的解也不必唯一。能保证的是在一个性质好的 KKT 点附近，有一段路径通向它。

定理 24.5 KKT 点附近的路径 设 f、g_i、h_j 二阶连续可微，$(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 是 KKT 点，并满足三个条件：活动约束梯度与全部等式约束梯度线性无关；严格互补，即活动约束的乘子都为正；在临界方向上有

$$\boldsymbol{d}^{\top} \nabla^2_{\boldsymbol{x}\boldsymbol{x}} \mathcal{L}(\boldsymbol{x}^\star, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) \boldsymbol{d} > 0, \tag{24.14}$$

这里临界方向指满足 $\boldsymbol{A}\boldsymbol{d} = \boldsymbol{0}$、对活动约束 $\nabla g_i^{\top} \boldsymbol{d} = 0$ 的非零 $\boldsymbol{d}$。则存在 $\bar{\mu} > 0$ 和连续可微的曲线 $\mu \mapsto (\boldsymbol{x}(\mu), \boldsymbol{\lambda}(\mu), \boldsymbol{\nu}(\mu))$，在 $(0, \bar{\mu})$ 上满足方程组 (24.11)，$\mu \downarrow 0$ 时趋于该 KKT 点，并且 $\boldsymbol{x}(\mu)$ 是子问题 (24.7)的严格局部极小点。

证明 设 $\boldsymbol{s} = -\boldsymbol{g}$，把方程组写成关于 $(\boldsymbol{x}, \boldsymbol{s}, \boldsymbol{\lambda}, \boldsymbol{\nu})$ 的方程 $\boldsymbol{F}(\cdot) = \mu \boldsymbol{e}$，其中 $\boldsymbol{e}$ 只在互补方程处为 1。在 $\mu = 0$ 的 KKT 点处用隐函数定理，只需证明 Jacobian 矩阵非奇异，也就是下面的齐次方程只有零解：

$$\begin{aligned} &\boldsymbol{W}\boldsymbol{d} + \boldsymbol{J}^{\top}\boldsymbol{d}_{\lambda} + \boldsymbol{A}^{\top}\boldsymbol{d}_{\nu} = \boldsymbol{0}, \qquad \boldsymbol{A}\boldsymbol{d} = \boldsymbol{0}, \\ &\boldsymbol{J}\boldsymbol{d} + \boldsymbol{d}_{s} = \boldsymbol{0}, \qquad \lambda_i^\star d_{s,i} + s_i^\star d_{\lambda,i} = 0. \end{aligned}$$

这里 $\boldsymbol{W} = \nabla^2_{\boldsymbol{x}\boldsymbol{x}} \mathcal{L}$。

对活动约束，$s_i^\star = 0$、$\lambda_i^\star > 0$，互补方程给出 $d_{s,i} = 0$，于是 $\nabla g_i^{\top} \boldsymbol{d} = 0$。对不活动约束，$\lambda_i^\star = 0$、$s_i^\star > 0$，互补方程给出 $d_{\lambda,i} = 0$。

用 $\boldsymbol{d}^{\top}$ 左乘第一个方程，再用 $\boldsymbol{A}\boldsymbol{d} = \boldsymbol{0}$，得到

$$\boldsymbol{d}^{\top}\boldsymbol{W}\boldsymbol{d} = -\sum_i d_{\lambda,i} \nabla g_i^{\top} \boldsymbol{d} = 0.$$

求和中每一项都为零：活动约束的 $\nabla g_i^{\top} \boldsymbol{d} = 0$，不活动约束的 $d_{\lambda,i} = 0$。由条件 (24.14)，$\boldsymbol{d} = \boldsymbol{0}$。

于是 $\boldsymbol{d}_s = \boldsymbol{0}$，第一个方程只剩活动约束与等式约束的梯度组合等于零，由线性无关性，$\boldsymbol{d}_{\lambda}$、$\boldsymbol{d}_{\nu}$ 为零。隐函数定理给出连续可微的解曲线。对小的 $\mu > 0$，活动约束 $s_i = \mu/\lambda_i > 0$，不活动约束 $\lambda_i = \mu/s_i > 0$，所以解满足正性要求。

最后证局部极小。把式 (24.9)和 $\lambda_i = \mu/s_i$ 代入 $\nabla^2 B_{\mu}$，并计入等式约束的曲率，子问题的 Lagrange Hessian 是 $\boldsymbol{W} + \boldsymbol{J}^{\top}\boldsymbol{S}^{-1}\boldsymbol{\Lambda}\boldsymbol{J}$，其中 $\boldsymbol{S}$、$\boldsymbol{\Lambda}$ 是对角矩阵。假设存在 $\mu_k \downarrow 0$ 和单位向量 $\boldsymbol{d}_k$，满足 $\boldsymbol{A}\boldsymbol{d}_k = \boldsymbol{0}$，而二次型非正。则

$$\sum_i \frac{\lambda_i}{s_i} (\nabla g_i^{\top} \boldsymbol{d}_k)^2 \le -\boldsymbol{d}_k^{\top} \boldsymbol{W} \boldsymbol{d}_k.$$

> 右端有界，而活动约束的 $\lambda_i/s_i \to \infty$，所以极限方向 $\bar{\boldsymbol{d}}$ 满足 $\nabla g_i^{\top}\bar{\boldsymbol{d}} = 0$。于是 $\bar{\boldsymbol{d}}$ 是临界方向，并且 $\bar{\boldsymbol{d}}^{\top}\boldsymbol{W}\bar{\boldsymbol{d}} \le 0$，与式 (24.14)矛盾。 ■

定理的三个条件各管一件事。线性无关保证乘子唯一，严格互补保证每条约束在极限时明确属于活动或不活动的一侧，式 (24.14)保证弯曲方向上是极小而不是鞍点。

隐函数定理还给出路径在 $\mu = 0$ 处的切线。在贯穿例中，$\boldsymbol{W} = \operatorname{diag}(3,1)$，$s_2^{\star} = 3$，把解曲线对 μ 求导，得到

$$\lambda_2'(0) = \frac{1}{3}, \qquad s_1'(0) = 1.$$

线性化的方程剩下三个未知量 x_1'、x_2'、λ_1'，解出

$$\boldsymbol{x}'(0) = \Big(-\frac{8}{21}, \frac{5}{21}\Big)^{\top}, \qquad \lambda_1'(0) = \frac{4}{7}.$$

所以 $\boldsymbol{x}(\mu) \approx (1,1)^{\top} + \mu(-8/21, 5/21)^{\top}$。取 $\mu = 0.01$，预测 $(0.9962, 1.0024)^{\top}$，数值解是 $(0.9962, 1.0024)^{\top}$。目标的一阶变化是 $\nabla f^{\top}\boldsymbol{x}'(0) = 1$，这正是前面看到的“误差约等于 μ”。

路径可以断开，也可能通向较差的解　定理 24.5的 $\bar{\mu}$ 可以很小，它不保证路径能一直延伸到大的 μ。下面的一维例子说明会发生什么。在 $x > 0$ 上取 $f'(x) = (x-1)(x-3)(x-4)$，它在 $x = 1$ 和 $x = 4$ 处有局部极小，$f(4) - f(1) = 9/4$，所以 $x = 1$ 是全局解。

障碍驻定条件 $f'(x) = \mu/x$ 可以反解成

$$\mu = x(x-1)(x-3)(x-4).$$

要求 $\mu > 0$，可行的 x 只有 $(1,3)$ 和 $(4,\infty)$ 两段。第一段上 μ 先增后减，在 $x = 2$ 处达到最大值 $\mu = 4$。图 24.8(b) 中，极小点的分支从 $x = 1$ 出发，到 $\mu = 4$ 时与鞍点分支相撞，两者同时消失，这个点称为**折叠点**（fold point）。

$\mu > 4$ 时只剩 $x > 4$ 这一支。从大的 μ 出发沿路径减小参数，走到的是 $x = 4$，错过了全局解 $x = 1$。这条路径是连续的，算法并没有失败，只是路径根本不经过全局解。

24.1 障碍问题
24.2 原始—对偶内点法
24.2.1 扰动互补方程
24.2.2 Newton 方向
24.2.3 步长与中心性
24.3 初始化与精度
24.4 锥规划中的障碍
24.5 保证与计算成本
24.6 本章小结

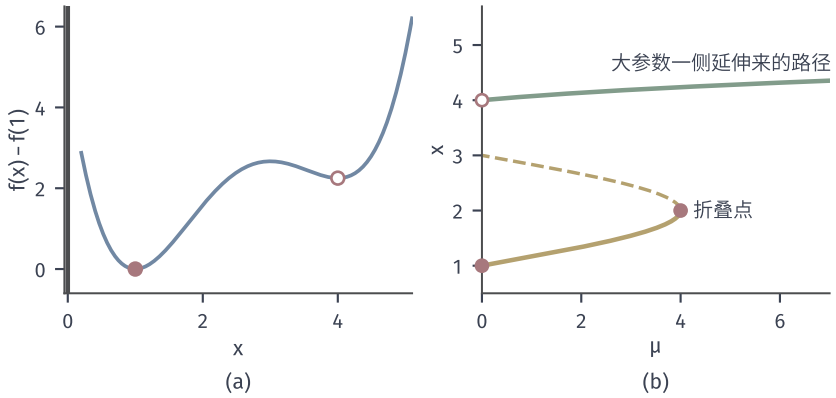


图 24.8 非凸的一维路径，$f'(x) = (x-1)(x-3)(x-4)$，$x > 0$。(a) 蓝线是目标，红点是全局解 $x = 1$，空心红点是局部解 $x = 4$。(b)(μ, x) 平面上的驻点集合：绿线是从大参数一侧延伸来的路径；黄线是 $(1, 3)$ 上的另一支，实线部分是局部极小点，虚线部分不是，两者在红点（折叠点 $(4, 2)$）相遇。

24.2 原始—对偶内点法

障碍法有两个不便之处。一维例子已经显示，参数减小之后，从旧碗底出发的 Newton 步可能完全不可信。另外它要求每个迭代点都严格满足 $\boldsymbol{g}(\boldsymbol{x}) < \boldsymbol{0}$，弯的约束使这件事代价不小。于是要问：把乘子和松弛都当作独立变量，同时更新，能否绕开这两点，又要付出什么代价？

24.2.1 扰动互补方程

方程组 (24.11)里，$-g_i$ 既是约束值，又是互补方程的一个因子。引入**松弛变量**（slack variable）$\boldsymbol{s} \in \mathbb{R}^m$，把它们分开：

$$
\begin{aligned}
\nabla f(\boldsymbol{x}) + \boldsymbol{J}(\boldsymbol{x})^{\top}\boldsymbol{\lambda} + \boldsymbol{A}(\boldsymbol{x})^{\top}\boldsymbol{\nu} &= \boldsymbol{0}, \\
\boldsymbol{h}(\boldsymbol{x}) &= \boldsymbol{0}, \\
\boldsymbol{g}(\boldsymbol{x}) + \boldsymbol{s} &= \boldsymbol{0}, \\
s_i \lambda_i &= \mu \quad (i = 1, \dots, m), \\
\boldsymbol{s} > \boldsymbol{0}, \quad \boldsymbol{\lambda} &> \boldsymbol{0}.
\end{aligned}
\tag{24.15}
$$

这里的乘子 $\boldsymbol{\lambda}$ 沿用第 17章的符号。要留意 $\boldsymbol{s}$ 的角色变了：第 4章的 $\boldsymbol{s}$ 是对偶松弛，这里的 $\boldsymbol{s}$ 是原始松弛，对偶一侧的正变量是 $\boldsymbol{\lambda}$。表 24.1列出两章量的对应，取 $\boldsymbol{g}(\boldsymbol{x}) = -\boldsymbol{x}$ 就回到线性规划。

量	线性规划	一般约束
原始侧的正变量	$\boldsymbol{x}$	$\boldsymbol{s} = -\boldsymbol{g}(\boldsymbol{x})$
对偶侧的正变量	$\boldsymbol{s}$	$\boldsymbol{\lambda}$
扰动互补	$x_i s_i = \mu$	$s_i \lambda_i = \mu$
不等式约束数	n	m
Jacobian	$-\boldsymbol{I}$，常数	$\boldsymbol{J}(\boldsymbol{x})$，随点变化
等式的 Jacobian	$\boldsymbol{A}$，常数	$\boldsymbol{A}(\boldsymbol{x})$，随点变化
二阶信息	无	Lagrange Hessian

表 24.1　线性规划内点法与一般约束内点法中各量的对应。

正性和参数各管什么　方程组 (24.15)有两类要求，作用不同。$\boldsymbol{s}, \boldsymbol{\lambda} > \boldsymbol{0}$ 是内部性，它不是方程，而是对解的筛选。$\mu > 0$ 是中心性，它要求所有乘积相等，从而把组合选择（哪个因子为零）换成一条光滑的曲线。

去掉正性，方程会多出不该要的解。回到一维例子 $\min x$、$x^2 - 1 \le 0$，方程组是

$$1 + 2\lambda x = 0, \qquad x^2 - 1 + s = 0, \qquad s\lambda = \mu.$$

消去 λ 和 s，得到 $1 - x^2 + 2\mu x = 0$，它有两个根 $x = \mu \pm \sqrt{\mu^2 + 1}$。

取 $\mu = 3/4$。根 $x = -1/2$ 给出 $s = 3/4$、$\lambda = 1$，这是碗底。根 $x = 2$ 给出

$$s = -3, \qquad \lambda = -\frac{1}{4}, \qquad s\lambda = \frac{3}{4}.$$

方程全部满足，两个因子却都是负的，这个点在可行域之外。$\mu \to 0$ 时它趋于 $x = 1$，那是原问题的最大点。所以正性不是可有可无的附加条件，它把算法挡在对的那一支上。

残差小、乘积小和已经最优是三回事　方程组 (24.15)令人误以为只要把某个量压小就算成功。在贯穿例的点 $\boldsymbol{x} = (1, 2)^{\mathsf{T}}$、$\boldsymbol{s} = (1, 2)^{\mathsf{T}}$ 上看两种选择。

第一种取 $\boldsymbol{\lambda} = (10^{-3}, 10^{-3})^{\mathsf{T}}$。这时松弛方程精确满足，两个乘积分别是 10^{-3} 和 2×10^{-3}，都很小，驻定残差却是

$$\nabla f + \boldsymbol{J}^{\mathsf{T}} \boldsymbol{\lambda} \approx (-1.998,\ 2)^{\mathsf{T}},$$

离 $\boldsymbol{0}$ 很远。互补小，只说明 $s_i \lambda_i$ 小，不说明点接近最优。

第二种取 $\mu = 1$ 的中心点。这时所有方程残差都是零，乘积却等于 1。残差为零说明的是“解对了当前的 μ”，而不是解对了原问题。只有方程残差和互补量同时小，才接近 KKT 点。在非凸问题上，即便接近 KKT 点，也还要另外判断它是不是极小点。

24.1 障碍问题
24.2 原始—对偶内点法
24.2.1 扰动互补方程
24.2.2 Newton 方向
24.2.3 步长与中心性
24.3 初始化与精度
24.4 锥规划中的障碍
24.5 保证与计算成本
24.6 本章小结

24.2.2 Newton 方向

主要思想：线性化扰动方程 当前点记为 $(\boldsymbol{x},\boldsymbol{s},\boldsymbol{\lambda},\boldsymbol{\nu})$，只要求 $\boldsymbol{s},\boldsymbol{\lambda}>\mathbf{0}$。平均互补量和本轮的目标参数是

$$\mu=\frac{\boldsymbol{s}^{\top}\boldsymbol{\lambda}}{m},\qquad \hat{\mu}=\sigma\mu,\quad \sigma\in[0,1). \tag{24.16}$$

定义四个残差，它们分别度量驻定、等式、松弛方程和互补目标还差多少：

$$\begin{aligned}\boldsymbol{r}_{\mathrm{d}}&=\nabla f(\boldsymbol{x})+\boldsymbol{J}(\boldsymbol{x})^{\top}\boldsymbol{\lambda}+\boldsymbol{A}(\boldsymbol{x})^{\top}\boldsymbol{\nu},\\ \boldsymbol{r}_{\mathrm{e}}&=\boldsymbol{h}(\boldsymbol{x}),\qquad \boldsymbol{r}_{\mathrm{p}}=\boldsymbol{g}(\boldsymbol{x})+\boldsymbol{s},\\ \boldsymbol{r}_{\mathrm{c}}&=\hat{\mu}\mathbf{1}-\boldsymbol{S}\boldsymbol{\Lambda}\mathbf{1},\end{aligned} \tag{24.17}$$

其中 $\boldsymbol{S}=\operatorname{diag}(\boldsymbol{s})$，$\boldsymbol{\Lambda}=\operatorname{diag}(\boldsymbol{\lambda})$。

对方程组作 Newton 线性化，需要各方程对变量的导数。第一个方程对 $\boldsymbol{x}$ 求导，得到Lagrange Hessian（Lagrangian Hessian）

$$\boldsymbol{W}=\nabla^2 f(\boldsymbol{x})+\sum_{i=1}^{m}\lambda_i\nabla^2 g_i(\boldsymbol{x})+\sum_{j=1}^{p}\nu_j\nabla^2 h_j(\boldsymbol{x}), \tag{24.18}$$

对 $\boldsymbol{\lambda}$、$\boldsymbol{\nu}$ 求导得到 $\boldsymbol{J}^{\top}$、$\boldsymbol{A}^{\top}$。其余方程的导数可以直接读出。于是方向由下面的线性方程组确定：

$$\begin{bmatrix}\boldsymbol{W}&\mathbf{0}&\boldsymbol{J}^{\top}&\boldsymbol{A}^{\top}\\ \boldsymbol{J}&\boldsymbol{I}&\mathbf{0}&\mathbf{0}\\ \boldsymbol{A}&\mathbf{0}&\mathbf{0}&\mathbf{0}\\ \mathbf{0}&\boldsymbol{\Lambda}&\boldsymbol{S}&\mathbf{0}\end{bmatrix}\begin{bmatrix}\Delta\boldsymbol{x}\\ \Delta\boldsymbol{s}\\ \Delta\boldsymbol{\lambda}\\ \Delta\boldsymbol{\nu}\end{bmatrix}=\begin{bmatrix}-\boldsymbol{r}_{\mathrm{d}}\\ -\boldsymbol{r}_{\mathrm{p}}\\ -\boldsymbol{r}_{\mathrm{e}}\\ \boldsymbol{r}_{\mathrm{c}}\end{bmatrix}. \tag{24.19}$$

和第 4章的方程组比较，第四行结构不变，新增的是左上角的 $\boldsymbol{W}$，以及 $\boldsymbol{J}$、$\boldsymbol{A}$ 每轮都要重新计算。线性规划中 $\boldsymbol{W}=\mathbf{0}$。

消元与鞍点结构 图 24.9是消元的路线。由第二行，松弛的方向是

$$\Delta\boldsymbol{s}=-\boldsymbol{r}_{\mathrm{p}}-\boldsymbol{J}\Delta\boldsymbol{x}. \tag{24.20}$$

由第四行，乘子的方向是

$$\Delta\boldsymbol{\lambda}=\boldsymbol{S}^{-1}\bigl(\boldsymbol{r}_{\mathrm{c}}-\boldsymbol{\Lambda}\Delta\boldsymbol{s}\bigr). \tag{24.21}$$

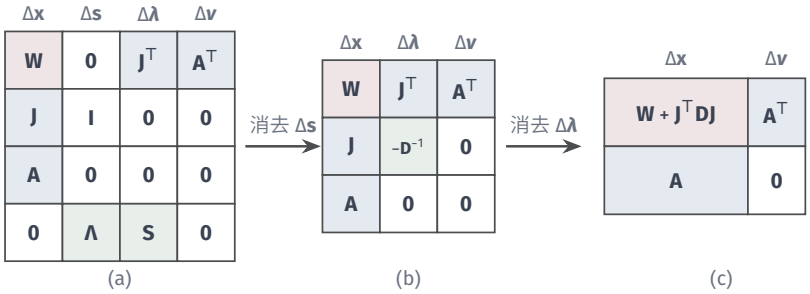


图 24.9 Newton 方程组的三种等价形式，顶部标出每列对应的方向。红底是含曲率的块，蓝底是约束 Jacobian，绿底是对角块，$\boldsymbol{D}=\boldsymbol{S}^{-1}\boldsymbol{\Lambda}$。(a) 式 (24.19)；(b) 消去 $\Delta\boldsymbol{s}$ 后的对称鞍点形式；(c) 再消去 $\Delta\boldsymbol{\lambda}$ 后的压缩形式。

把式 (24.20)代入式 (24.21)，再代入第一行，$\Delta\boldsymbol{\lambda}$ 被消去，只剩 $\Delta\boldsymbol{x}$ 和 $\Delta\boldsymbol{\nu}$。记对角矩阵 $\boldsymbol{D}=\boldsymbol{S}^{-1}\boldsymbol{\Lambda}$，以及

$$\tilde{\boldsymbol{H}}=\boldsymbol{W}+\boldsymbol{J}^{\top}\boldsymbol{D}\boldsymbol{J},\qquad \boldsymbol{b}=-\boldsymbol{r}_{\mathrm{d}}-\boldsymbol{J}^{\top}\boldsymbol{S}^{-1}\left(\boldsymbol{r}_{\mathrm{c}}+\boldsymbol{\Lambda}\boldsymbol{r}_{\mathrm{p}}\right). \tag{24.22}$$

方向 $\Delta\boldsymbol{x}$、$\Delta\boldsymbol{\nu}$ 满足压缩后的鞍点方程

$$\begin{bmatrix}\tilde{\boldsymbol{H}} & \boldsymbol{A}^{\top}\\ \boldsymbol{A} & \boldsymbol{0}\end{bmatrix}\begin{bmatrix}\Delta\boldsymbol{x}\\ \Delta\boldsymbol{\nu}\end{bmatrix}=\begin{bmatrix}\boldsymbol{b}\\ -\boldsymbol{r}_{\mathrm{e}}\end{bmatrix}. \tag{24.23}$$

$\tilde{\boldsymbol{H}}$ 的两部分对应障碍的两种作用：$\boldsymbol{J}^{\top}\boldsymbol{D}\boldsymbol{J}$ 在约束法向上加刚度，$\boldsymbol{W}$ 保留目标和约束的弯曲。在式 (24.19)的第二种写法里，只消去 $\Delta\boldsymbol{s}$，保留 $\Delta\boldsymbol{\lambda}$，得到的矩阵是

$$\begin{bmatrix}\boldsymbol{W} & \boldsymbol{J}^{\top} & \boldsymbol{A}^{\top}\\ \boldsymbol{J} & -\boldsymbol{D}^{-1} & \boldsymbol{0}\\ \boldsymbol{A} & \boldsymbol{0} & \boldsymbol{0}\end{bmatrix}. \tag{24.24}$$

压缩形式维数小，鞍点形式稀疏性好，第 24.5节比较它们的代价。

举一个带等式约束的算例，看 $\boldsymbol{A}$ 的作用。取下面的矩阵 $\tilde{\boldsymbol{H}}$ 和右端 $\boldsymbol{b}$（稍后的计算过程会在贯穿例的第一轮得到它们），再加一条等式约束 $x_1-x_2+1=0$，当前点 $(1,2)$ 满足它，所以 $r_{\mathrm{e}}=0$：

$$\tilde{\boldsymbol{H}}=\begin{bmatrix}7 & -2\\ -2 & 9/4\end{bmatrix},\qquad \boldsymbol{b}=\begin{bmatrix}8/5\\ -19/10\end{bmatrix},\qquad \boldsymbol{A}=\begin{bmatrix}1 & -1\end{bmatrix}.$$

由 $\boldsymbol{A}\Delta\boldsymbol{x}=0$，方向只能取 $\Delta\boldsymbol{x}=\tau(1,1)^{\top}$。用 $(1,1)$ 左乘第一块方程，$\Delta\nu$ 相互抵消，得到

$$\tfrac{21}{4}\tau=-\tfrac{3}{10},\qquad \text{即}\qquad \tau=-\frac{2}{35}.$$

再由第一行，$5\tau+\Delta\nu=8/5$，于是 $\Delta\nu=66/35$。等式约束的作用是把方向压进切平面，这和第 20章的等式约束二次规划一样。

与障碍法的 Newton 方向比较 若 $\boldsymbol{s}=-\boldsymbol{g}(\boldsymbol{x})$，$\boldsymbol{\lambda}=\mu\boldsymbol{S}^{-1}\mathbf{1}$，则 $\tilde{\boldsymbol{H}}=\nabla^2 B_\mu$，两种方法在这一点上的矩阵相同。差别出现在其他点：参数一降，障碍法的乘子估计立刻变成 μ^+/s_i，原始—对偶方法的 λ_i 则留在当前值，由方程去修正。

回到一维例子，站在 $x=-1/2$、$s=3/4$、$\lambda=1$，目标参数 $\hat{\mu}=0.05$。这时

$$W=2,\quad J=-1,\quad D=\frac{4}{3},\quad \tilde{H}=\frac{10}{3},\quad r_{\mathrm{c}}=0.05-0.75=-0.7.$$

由式 (24.22)，$b=-J\,r_{\mathrm{c}}/s=-14/15$，于是

$$\Delta x=-0.28,\qquad \Delta s=-0.28,\qquad \Delta\lambda=-0.56.$$

单位步得到 $x=-0.78$、$s=0.47$、$\lambda=0.44$，都留在正确的一侧。同样的起点和目标参数，障碍法的 Newton 步是 -4.2。这里的差别和第 4章线性化 $x_i s_i=\mu$ 而不线性化 $s_i=\mu/x_i$ 是同一个原因。

曲率让残差不再按比例下降 线性规划中，走步长 α 后等式残差精确地乘以 $1-\alpha$。这个性质来自约束是线性的。现在对松弛方程作 Taylor 展开，走完步长 α，残差变成

$$\boldsymbol{r}_{\mathrm{p}}^{+}=(1-\alpha)\boldsymbol{r}_{\mathrm{p}}+\boldsymbol{\rho}(\alpha),\tag{24.25}$$

其中二阶余项是

$$\boldsymbol{\rho}(\alpha)=\boldsymbol{g}(\boldsymbol{x}+\alpha\Delta\boldsymbol{x})-\boldsymbol{g}(\boldsymbol{x})-\alpha\boldsymbol{J}\Delta\boldsymbol{x}.$$

若 ∇g_i 是 L_g-Lipschitz 的，则余项的大小满足

$$|\rho_i(\alpha)|\le\tfrac{1}{2}L_g\alpha^2\|\Delta\boldsymbol{x}\|_2^2.$$

贯穿例的 $g_1=x_1^2-x_2$ 是二次的，余项可以精确写出：

$$\rho_1(\alpha)=\alpha^2\Delta x_1^2.$$

图 24.10取一个可行域外的点。线性模型认为约束边界是黄色的切线，走完单位步正好到达；实际约束是抛物线，单位步之后的残差不是零，而是 $\Delta x_1^2\approx 0.746$。

这个现象还有一个后果：即使当前点满足 $\boldsymbol{r}_{\mathrm{p}}=\mathbf{0}$，走一步后也可能变成非零。原始可行性在线性规划中可以一旦达到就永远保持，这里不能。

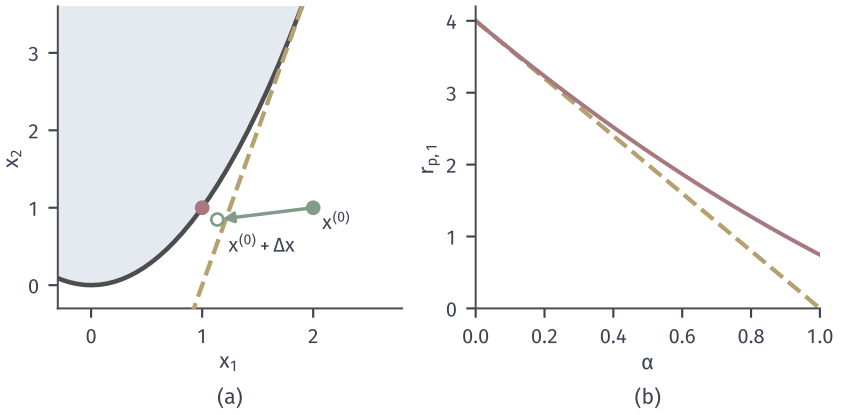


图 24.10　弯的约束使线性化产生误差，贯穿例，起点 $\boldsymbol{x}^{(0)}=(2,1)$、$\boldsymbol{s}=(1,3)$、$\boldsymbol{\lambda}=(1,1/3)$、$\sigma=0.2$。(a) 深灰粗线是真实边界，黄色虚线是在 $\boldsymbol{x}^{(0)}$ 处线性化的边界，绿色箭头是 Newton 步，红点是 $\boldsymbol{x}^{\star}$。(b) 红线是实际残差 $r_{\mathrm{p},1}$，黄色虚线是线性模型预测的 $(1-\alpha)r_{\mathrm{p},1}$，$\alpha=1$ 时两者相差 Δx_1^2。

线性系统可解，不等于方向好用　方程组 (24.23)何时有唯一解，答案和约化 Hessian 有关。

> **引理 24.6　Newton 方程的解**　设 $\boldsymbol{s},\boldsymbol{\lambda}>\boldsymbol{0}$，$\boldsymbol{A}$ 满行秩，$\tilde{\boldsymbol{H}}$ 在 $\boldsymbol{A}$ 的零空间上正定，即 $\boldsymbol{A}\boldsymbol{d}=\boldsymbol{0}$、$\boldsymbol{d}\neq\boldsymbol{0}$ 时 $\boldsymbol{d}^{\top}\tilde{\boldsymbol{H}}\boldsymbol{d}>0$。则方程组 (24.19)有唯一解。

证明　消元的每一步都是等价变形，所以只需证明压缩矩阵非奇异。设

$$\tilde{\boldsymbol{H}}\boldsymbol{d}+\boldsymbol{A}^{\top}\boldsymbol{w}=\boldsymbol{0},\qquad \boldsymbol{A}\boldsymbol{d}=\boldsymbol{0}.$$

用 $\boldsymbol{d}^{\top}$ 左乘第一式，并用第二式，得到

$$\boldsymbol{d}^{\top}\tilde{\boldsymbol{H}}\boldsymbol{d}=0.$$

由正定性 $\boldsymbol{d}=\boldsymbol{0}$。于是 $\boldsymbol{A}^{\top}\boldsymbol{w}=\boldsymbol{0}$，由满行秩 $\boldsymbol{w}=\boldsymbol{0}$。 ■

这个条件比“系数矩阵非奇异”强。矩阵非奇异时方程也有唯一解，但方向可能完全不对。下面的引理说明正定性的真正用途：它保证方向使障碍目标下降。这里的障碍目标把松弛也当作变量，写成

$$\psi_{\hat{\mu}}(\boldsymbol{x},\boldsymbol{s})=f(\boldsymbol{x})-\hat{\mu}\sum_{i=1}^{m}\log s_i.$$

引理 24.7 方向与障碍目标 设 $\boldsymbol{r}_{\mathrm{p}}=\boldsymbol{0}$，$\boldsymbol{r}_{\mathrm{e}}=\boldsymbol{0}$，方向由式 (24.19)给出，其中目标参数取 $\hat{\mu}$。则 $\psi_{\hat{\mu}}$ 沿方向的一阶变化满足

$$\nabla f^{\top}\Delta\boldsymbol{x}-\hat{\mu}\,\boldsymbol{1}^{\top}\boldsymbol{S}^{-1}\Delta\boldsymbol{s}=-\Delta\boldsymbol{x}^{\top}\tilde{\boldsymbol{H}}\Delta\boldsymbol{x}. \tag{24.26}$$

证明 由 $\boldsymbol{r}_{\mathrm{d}}$ 的定义和 $\boldsymbol{A}\Delta\boldsymbol{x}=\boldsymbol{0}$、$\boldsymbol{J}\Delta\boldsymbol{x}=-\Delta\boldsymbol{s}$，有

$$\nabla f^{\top}\Delta\boldsymbol{x}=\boldsymbol{r}_{\mathrm{d}}^{\top}\Delta\boldsymbol{x}+\boldsymbol{\lambda}^{\top}\Delta\boldsymbol{s}.$$

互补残差满足

$$\boldsymbol{S}^{-1}\boldsymbol{r}_{\mathrm{c}}=\hat{\mu}\boldsymbol{S}^{-1}\boldsymbol{1}-\boldsymbol{\lambda}.$$

用 $\Delta\boldsymbol{x}^{\top}$ 左乘式 (24.23)的第一块，并代入上式，得到

$$\Delta\boldsymbol{x}^{\top}\tilde{\boldsymbol{H}}\Delta\boldsymbol{x}=-\boldsymbol{r}_{\mathrm{d}}^{\top}\Delta\boldsymbol{x}+(\hat{\mu}\boldsymbol{S}^{-1}\boldsymbol{1}-\boldsymbol{\lambda})^{\top}\Delta\boldsymbol{s}.$$

由第二式解出 $\boldsymbol{r}_{\mathrm{d}}^{\top}\Delta\boldsymbol{x}$，代入第一式，$\boldsymbol{\lambda}^{\top}\Delta\boldsymbol{s}$ 相互抵消，即得结论。 ■

所以 $\tilde{\boldsymbol{H}}$ 在切空间上不正定时，$\Delta\boldsymbol{x}$ 可能是上升方向。图 24.11取圆盘外部的例子，$\mu=0.1$，在 $\boldsymbol{x}=(0.35,1.08)^{\top}$ 处的特征值是

$$-0.320,\qquad 7.352.$$

Newton 方向的一阶变化是 $\nabla B_{\mu}^{\top}\boldsymbol{d}=+0.947$，它是上升方向，指向鞍点。系数矩阵非奇异，线性方程解得毫无困难，得到的却是错误的方向。

补救办法是**矩阵正则化**（matrix regularization）：把 $\tilde{\boldsymbol{H}}$ 换成 $\tilde{\boldsymbol{H}}+\delta_{\mathrm{w}}\boldsymbol{I}$，$\delta_{\mathrm{w}}\geq 0$ 逐步增大，直到切空间上正定。例中取 $\delta_{\mathrm{w}}=0.47$，新方向的一阶变化是 -2.73，变成下降方向。

怎样判断切空间上正定？实际中不直接算切空间，而看鞍点矩阵的惯性，即正、负、零特征值的个数。$\boldsymbol{A}$ 满行秩时，$\tilde{\boldsymbol{H}}$ 在零空间上正定，当且仅当矩阵 (24.23)的惯性是 $(n,p,0)$。分解 $\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\top}$ 时可以直接读出惯性，所以试探 δ_{w} 只要重复分解。这个判据的证明要用到 Sylvester 惯性定律，读者可查阅专著[1]。

[1] J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

24.1 障碍问题
24.2 原始—对偶内点法
24.2.1 扰动互补方程
24.2.2 Newton 方向
24.2.3 步长与中心性
24.3 初始化与精度
24.4 锥规划中的障碍
24.5 保证与计算成本
24.6 本章小结

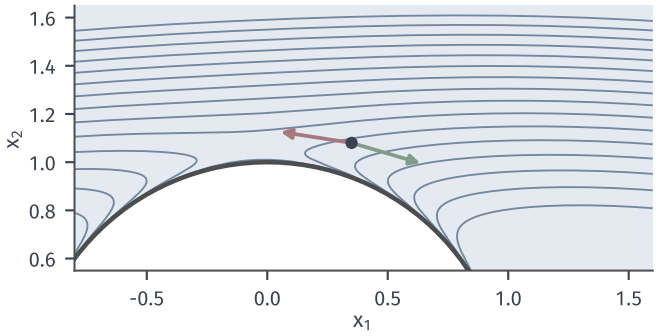


图 24.11 曲率不定时的方向，圆盘外部的例子，$\mu = 0.1$。深灰粗线是约束边界，蓝线是 B_μ 的等值线，黑点是当前点。红色箭头是未修正的 Newton 方向，指向上升一侧的鞍点（为便于观察，按比例缩短）；绿色箭头是加上 $\delta_w \boldsymbol{I}$ 之后的方向，沿下降方向走向右侧的极小点。

另一类困难来自约束退化。若活动约束或等式约束的梯度线性相关，$\boldsymbol{A}$ 不再满行秩，矩阵奇异或接近奇异。常用的办法是在右下角加上 $-\delta_c \boldsymbol{I}$，相当于允许等式约束有微小的违反。数值尺度也要处理：把某条约束乘以 1000，$\boldsymbol{D}$ 和残差的数值都跟着变，通常先对目标和约束的梯度作缩放。这些修改的代价是方向不再是真正的 Newton 方向，第 24.3.2小节会说明为什么最后要按未经修改的问题检查结果。

24.2.3 步长与中心性

得到方向后，还要回答走多远。这里有三件事彼此独立：不能越过边界，这一步要确实有进展，迭代点不能离路径太远。

到边界的比例规则 第一件事沿用第 4章的做法，只是作用在 $(\boldsymbol{s}, \boldsymbol{\lambda})$ 上：

$$\alpha_{\max} = \min\Big\{ \min_{\Delta s_i < 0} \frac{s_i}{-\Delta s_i},\ \min_{\Delta \lambda_i < 0} \frac{\lambda_i}{-\Delta \lambda_i} \Big\}, \qquad \alpha = \min\{1,\ \eta\, \alpha_{\max}\}, \tag{24.27}$$

其中 $\eta \in (0,1)$，没有负分量时约定 $\alpha_{\max} = +\infty$。

这条规则保护的是 $\boldsymbol{s} > \boldsymbol{0}$，而不是 $\boldsymbol{g}(\boldsymbol{x}) < \boldsymbol{0}$。当 $\boldsymbol{r}_{\mathrm{p}} \neq \boldsymbol{0}$ 时，$\boldsymbol{x}$ 可以暂时越过约束边界。这是原始—对偶方法相对于障碍法的自由，也是第 24.3.2小节必须检查原约束的原因。

实现中常对原始变量和对偶变量用不同的步长，因为线性规划中“单一步长让互补量精确下降”的理由在这里已经不成立。下面的算例为了便于手算，仍用单一步长。

残差检验 满足比例规则的步长仍可能太长，因为式 (24.25)的余项和 $\boldsymbol{W}$ 的变化都没有进入线性模型。最直接的检验是看方程残差有没有变小。把方程组写成 $\boldsymbol{F}_{\hat{\mu}}(\boldsymbol{z})=\boldsymbol{0}$，其中 $\boldsymbol{z}=(\boldsymbol{x},\boldsymbol{s},\boldsymbol{\lambda},\boldsymbol{\nu})$，要求

$$\|\boldsymbol{F}_{\hat{\mu}}(\boldsymbol{z}+\alpha\Delta\boldsymbol{z})\|_2 \le (1-c\,\alpha)\|\boldsymbol{F}_{\hat{\mu}}(\boldsymbol{z})\|_2, \tag{24.28}$$

其中 $c\in(0,1)$ 是小常数，不满足时把 α 减半。

引理 24.8 Newton 方向使残差下降 设 $\boldsymbol{F}_{\hat{\mu}}$ 连续可微，其 Jacobian 矩阵在 $\boldsymbol{z}$ 处非奇异，$\Delta\boldsymbol{z}$ 是 Newton 方向，$\boldsymbol{F}_{\hat{\mu}}(\boldsymbol{z})\neq\boldsymbol{0}$。则 $\alpha>0$ 足够小时，式 (24.28)成立。

证明 记

$$\Theta(\alpha)=\tfrac{1}{2}\|\boldsymbol{F}_{\hat{\mu}}(\boldsymbol{z}+\alpha\Delta\boldsymbol{z})\|_2^2.$$

由 Newton 方程 $\boldsymbol{G}\Delta\boldsymbol{z}=-\boldsymbol{F}$，其中 $\boldsymbol{G}$ 是 Jacobian 矩阵，有

$$\Theta'(0)=\boldsymbol{F}^{\top}\boldsymbol{G}\Delta\boldsymbol{z}=-\|\boldsymbol{F}\|_2^2.$$

于是残差范数的展开是

$$\sqrt{2\Theta(\alpha)}=\|\boldsymbol{F}\|_2(1-\alpha)+o(\alpha).$$

而 $c<1$，所以 α 足够小时不等式成立。 ■

这个检验简单，但有明显的盲区：它只看方程残差，分不清极小点和鞍点。方程组的任何解都能把它压到零，包括前面的 $x=2$（若不靠正性挡住）和各种局部极大点。所以在非凸问题上，更常用的检验还要看目标。

过滤器 一个直接想法是把约束违反量和障碍目标合成一个数，用它来比较。这需要一个权重，取大了算法只管可行，取小了只管目标。**过滤器**（filter）绕开这个权重，它把每一步看成二维平面上的一个点：

$$\theta(\boldsymbol{z})=\big\|\big(\boldsymbol{h}(\boldsymbol{x}),\ \boldsymbol{g}(\boldsymbol{x})+\boldsymbol{s}\big)\big\|_2,\qquad \psi_{\mu}(\boldsymbol{x},\boldsymbol{s})=f(\boldsymbol{x})-\mu\sum_{i=1}^{m}\log s_i. \tag{24.29}$$

算法保存一些历史点 (θ_l,ψ_l)，试探点只要不被其中任何一个点支配，就可以接受，也就是对每个 l，要么 θ 比 θ_l 小，要么 ψ_μ 比 ψ_l 小。图 24.12中有三个历史点 $(0.2,4)$、$(0.5,3)$、$(1,2.5)$。

试探点 A= $(0.3,3.2)$ 的 θ 比 $(0.5,3)$ 和 $(1,2.5)$ 都小，ψ_μ 又比 $(0.2,4)$ 小，所以被接受。试探点 B= $(0.6,3.5)$ 的两个分量都比 $(0.5,3)$ 差，被拒绝。两项指标各有高低的点互不否定，两项都差的点才被淘汰。

实际的过滤器要求有一定幅度的改进，例如 $\theta \le (1-\gamma_\theta)\theta_l$ 或 $\psi_\mu \le \psi_l - \gamma_\psi \theta_l$，否则可能无穷地接受改进极小的点。如果步长被缩到极小仍不能接受，算法转入**可行性恢复**（feasibility restoration）阶段，暂时放下目标，只减小 θ。

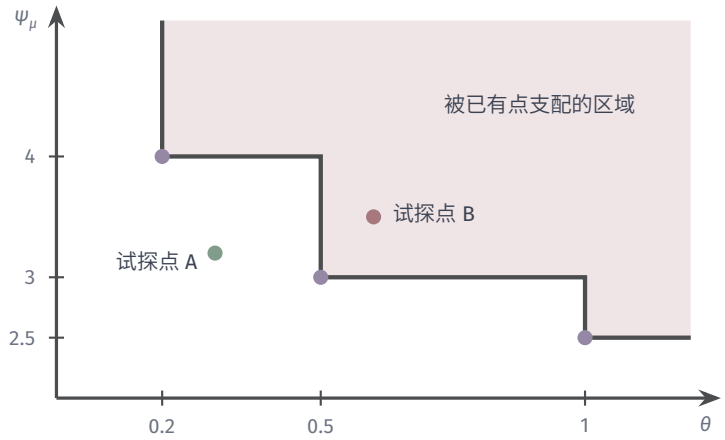


图 24.12 过滤器。横轴是约束违反量 θ，纵轴是障碍目标 ψ_μ。紫点是已保存的历史点，红底是被它们支配的区域。绿点 A 不被任何历史点支配，可以接受；红点 B 落在被支配区域内，被拒绝。

保持正性与靠近中心是两回事 到边界的比例规则只保证 $s_i, \lambda_i > 0$。点可以严格在内部，却让某个乘积比平均值小几千倍，这时下一轮的 Newton 步很可能被这个小乘积卡住。沿用第 4章的度量，定义中心性

$$\xi = \frac{\min_i s_i \lambda_i}{\mu} \in (0, 1]. \tag{24.30}$$

要求 $\xi \ge \gamma$（例如 $\gamma = 10^{-3}$）的集合称为**宽邻域**（wide neighborhood）。

图 24.13把贯穿例的迭代画在 $(s_1\lambda_1, s_2\lambda_2)$ 平面上。中心路径在这个平面上是对角线。绿线取 $\sigma = 0.2$，$\eta = 0.9$，轨迹贴着对角线，中心性最低为 0.49。

黄线取 $\sigma = 0.02$，$\eta = 0.9999$，每步都几乎走到边界，第一步就让中心性掉到 10^{-3}，再走两轮才恢复到 0.9 以上。正性两条线都保持了，靠近中心的程度却差别很大。

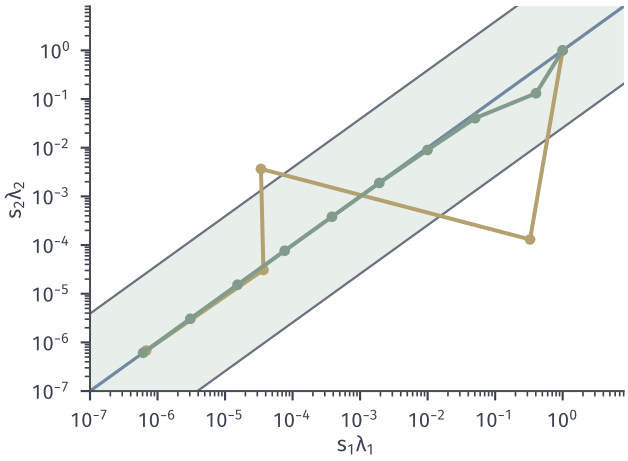


图 24.13 互补乘积平面，对数坐标，贯穿例。蓝线是 $s_1\lambda_1 = s_2\lambda_2$，即中心路径；浅绿带是宽邻域 $\xi \geq 0.05$，灰线是其边界。绿线是 $\sigma = 0.2$、$\eta = 0.9$ 的迭代，黄线是 $\sigma = 0.02$、$\eta = 0.9999$ 的迭代，后者离开了浅绿带。

计算过程 下面把一轮迭代写成具体步骤，并在例 (24.3)上逐轮计算。取固定的中心化参数 $\sigma = 0.2$、比例 $\eta = 0.9$、残差检验常数 $c = 10^{-4}$，容差 $\varepsilon = 10^{-6}$。例中没有等式约束，含 $\boldsymbol{A}$、$\boldsymbol{\nu}$ 的量都不出现。

变量

- $\boldsymbol{x} \in \mathbb{R}^n$：原始变量。$\boldsymbol{s} \in \mathbb{R}^m$：松弛，全部分量为正。
- $\boldsymbol{\lambda} \in \mathbb{R}^m$：不等式乘子，全部分量为正。$\boldsymbol{\nu} \in \mathbb{R}^p$：等式乘子。
- μ、$\hat{\mu}$：平均互补量和本轮的目标参数，由式 (24.16)给出。
- $\boldsymbol{r}_{\mathrm{d}}, \boldsymbol{r}_{\mathrm{e}}, \boldsymbol{r}_{\mathrm{p}}, \boldsymbol{r}_{\mathrm{c}}$：式 (24.17)的四个残差，维数依次是 n、p、m、m。
- $\boldsymbol{W}$、$\boldsymbol{D}$、$\tilde{\boldsymbol{H}}$、$\boldsymbol{b}$：Lagrange Hessian、对角缩放、压缩矩阵和右端，分别由式 (24.18)、(24.22)给出。
- $\Delta\boldsymbol{x}, \Delta\boldsymbol{s}, \Delta\boldsymbol{\lambda}, \Delta\boldsymbol{\nu}$：本轮的方向；$\alpha_{\max}, \alpha$：最大步长和实际步长。

初始化 取 $\boldsymbol{x}^{(0)}$、$\boldsymbol{s}^{(0)} > \boldsymbol{0}$、$\boldsymbol{\lambda}^{(0)} > \boldsymbol{0}$ 和 $\boldsymbol{\nu}^{(0)}$，令 $t = 0$；起点的选取由下一节讨论。例中取严格可行的点，并让两个乘积相等：

$$\boldsymbol{x}^{(0)} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \qquad \boldsymbol{s}^{(0)} = -\boldsymbol{g}(\boldsymbol{x}^{(0)}) = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \qquad \boldsymbol{\lambda}^{(0)} = \begin{bmatrix} 1 \\ 1/2 \end{bmatrix}.$$

每轮更新　在第 t 轮，以 $(\boldsymbol{x}^{(t)}, \boldsymbol{s}^{(t)}, \boldsymbol{\lambda}^{(t)}, \boldsymbol{\nu}^{(t)})$ 为当前点：

1. **计算残差并检查停止**。按式 (24.16)、(24.17)计算 μ 和残差。若 $\|\boldsymbol{r}_{\mathrm{d}}\|_\infty$、$\|\boldsymbol{r}_{\mathrm{e}}\|_\infty$、$\|\boldsymbol{r}_{\mathrm{p}}\|_\infty$ 和 $\max_i s_i\lambda_i$ 都不超过 ε，停止并输出当前点。

   例中第一轮 $\mu^{(0)} = 1$，$\hat{\mu} = 0.2$，

$$\boldsymbol{r}_{\mathrm{d}} = \begin{bmatrix} -2 \\ 2 \end{bmatrix} + \begin{bmatrix} 2 \\ -1/2 \end{bmatrix} = \begin{bmatrix} 0 \\ 3/2 \end{bmatrix}, \quad \boldsymbol{r}_{\mathrm{p}} = \boldsymbol{0}, \quad \boldsymbol{r}_{\mathrm{c}} = \begin{bmatrix} -4/5 \\ -4/5 \end{bmatrix}.$$

2. **形成压缩方程**。由式 (24.18)计算 $\boldsymbol{W}$，由式 (24.22)计算 $\tilde{\boldsymbol{H}}$ 和 $\boldsymbol{b}$。检查惯性，必要时加 $\delta_{\mathrm{w}}\boldsymbol{I}$。

   例中第一轮 $\lambda_1 = 1$，所以 $\boldsymbol{W} = \operatorname{diag}(3, 1)$，而 $\boldsymbol{D} = \operatorname{diag}(1, 1/4)$，$\boldsymbol{J}$ 的两行是 $(2, -1)$ 和 $(0, 1)$，所以

$$\tilde{\boldsymbol{H}} = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix} + \begin{bmatrix} 4 & -2 \\ -2 & 5/4 \end{bmatrix} = \begin{bmatrix} 7 & -2 \\ -2 & 9/4 \end{bmatrix}.$$

   又 $\boldsymbol{S}^{-1}\boldsymbol{r}_{\mathrm{c}} = (-4/5, -2/5)^{\mathsf{T}}$，于是

$$\boldsymbol{b} = -\begin{bmatrix} 0 \\ 3/2 \end{bmatrix} - \begin{bmatrix} -8/5 \\ 2/5 \end{bmatrix} = \begin{bmatrix} 8/5 \\ -19/10 \end{bmatrix}.$$

   这个矩阵的两个顺序主子式 7 和 $47/4$ 都是正的，因此正定，不需要修正。

3. **求方向**。解式 (24.23)得到 $\Delta\boldsymbol{x}$、$\Delta\boldsymbol{\nu}$，再由式 (24.20)、(24.21)回代。

   例中第一轮

$$\Delta\boldsymbol{x} = \left(-\frac{4}{235}, -\frac{202}{235}\right)^{\mathsf{T}} \approx (-0.0170,\ -0.8596)^{\mathsf{T}}.$$

   回代得到

$$\Delta\boldsymbol{s} \approx (-0.8255,\ 0.8596)^{\mathsf{T}}, \qquad \Delta\boldsymbol{\lambda} \approx (0.0255,\ -0.6149)^{\mathsf{T}}.$$

4. **确定步长**。由式 (24.27)得到候选 α，再用式 (24.28)（或过滤器）检验，不通过则把 α 减半。

   例中第一轮只有 s_1 和 λ_2 在减小，比值分别是 1.2113 和 0.8131，所以

$$\alpha_{\max} \approx 0.8131, \qquad \alpha = 0.9\,\alpha_{\max} \approx 0.7318.$$

   残差范数从 1.8788 降到 0.4559，检验通过，不需要回溯。

5. **更新**。令

$$\begin{aligned} \boldsymbol{x}^{(t+1)} &= \boldsymbol{x}^{(t)} + \alpha \Delta \boldsymbol{x}, \qquad \boldsymbol{s}^{(t+1)} = \boldsymbol{s}^{(t)} + \alpha \Delta \boldsymbol{s}, \\ \boldsymbol{\lambda}^{(t+1)} &= \boldsymbol{\lambda}^{(t)} + \alpha \Delta \boldsymbol{\lambda}, \qquad \boldsymbol{\nu}^{(t+1)} = \boldsymbol{\nu}^{(t)} + \alpha \Delta \boldsymbol{\nu}, \end{aligned} \tag{24.31}$$

然后令 $t \leftarrow t+1$，回到第 1 步。

例中第一轮

$$\boldsymbol{x}^{(1)} \approx (0.9875,\ 1.3709)^{\top},$$
$$\boldsymbol{s}^{(1)} \approx (0.3958,\ 2.6291)^{\top}, \qquad \boldsymbol{\lambda}^{(1)} \approx (1.0187,\ 0.0500)^{\top}.$$

这时 $\boldsymbol{r}_{\mathrm{p}}$ 不再为零，第一个分量是 $\alpha^2 \Delta x_1^2 \approx 1.55 \times 10^{-4}$，这正是式 (24.25) 的余项。

例中第二轮的中间量如下。当前 $\mu^{(1)} = 0.2673$，$\hat{\mu} = 0.0535$，两个乘积是 0.4032 和 0.1314，于是

$$\boldsymbol{r}_{\mathrm{d}} \approx (-0.0005,\ 0.4022)^{\top}, \qquad \boldsymbol{r}_{\mathrm{c}} \approx (-0.3498,\ -0.0780)^{\top}.$$

压缩矩阵和右端是

$$\tilde{\boldsymbol{H}} \approx \begin{bmatrix} 13.076 & -5.083 \\ -5.083 & 3.592 \end{bmatrix}, \qquad \boldsymbol{b} \approx \begin{bmatrix} 1.745 \\ -1.256 \end{bmatrix}.$$

解方程组并回代，得到

$$\Delta \boldsymbol{x} \approx (-0.0054,\ -0.3572)^{\top},$$
$$\Delta \boldsymbol{s} \approx (-0.3467,\ 0.3572)^{\top}, \qquad \Delta \boldsymbol{\lambda} \approx (0.0086,\ -0.0365)^{\top}.$$

这一轮 $\alpha_{\max} \approx 1.1418$，$0.9\alpha_{\max} > 1$，所以取 $\alpha = 1$。新的点是

$$\boldsymbol{x}^{(2)} \approx (0.9821,\ 1.0137)^{\top},$$
$$\boldsymbol{s}^{(2)} \approx (0.0492,\ 2.9863)^{\top}, \qquad \boldsymbol{\lambda}^{(2)} \approx (1.0273,\ 0.0135)^{\top}.$$

此后每轮都取 $\alpha = 1$，平均互补量几乎每轮乘以 0.2。表 24.2列出全部迭代。第 9 轮后所有残差和乘积都不超过 10^{-6}，算法停止。

t	$x_1^{(t)}$	$x_2^{(t)}$	$s_1^{(t)}$	$\lambda_1^{(t)}$	$\mu^{(t)}$	$\lVert r_{\mathrm{d}}\rVert_\infty$	$\lVert r_{\mathrm{p}}\rVert_\infty$	α
0	1.0000	2.0000	1.0000	1.0000	1.00	1.5	0	0.732
1	0.9875	1.3709	0.3958	1.0187	0.267	0.40	1.6e−4	1
2	0.9821	1.0137	0.0492	1.0272	0.0455	9.3e−5	2.9e−5	1
3	0.9963	1.0023	0.0099	1.0053	9.5e−3	6.2e−4	2.0e−4	1
4	0.9993	1.0005	0.0019	1.0011	1.9e−3	2.5e−5	8.9e−6	1
5	0.9999	1.0001	0.0004	1.0002	3.8e−4	1.0e−6	3.4e−7	1
6	1.0000	1.0000	0.0001	1.0000	7.6e−5	4.1e−8	1.4e−8	1
7	1.0000	1.0000	0.0000	1.0000	1.5e−5	1.6e−9	5.4e−10	1
8	1.0000	1.0000	0.0000	1.0000	3.1e−6	6.5e−11	2.2e−11	1
9	1.0000	1.0000	0.0000	1.0000	6.1e−7	2.6e−12	8.7e−13	

表 24.2　贯穿例的逐轮中间量，$\sigma = 0.2$、$\eta = 0.9$。第 t 行的 α 是从第 t 个点出发那一轮的步长。全部 α 都未经回溯。

最终得到

$$\hat{\boldsymbol{x}} \approx (1.0000,\, 1.0000)^{\mathsf{T}}, \qquad \hat{\boldsymbol{\lambda}} \approx (1.0000,\, 2\times 10^{-7})^{\mathsf{T}},$$

目标误差约 6.1×10^{-7}。第 3 轮的驻定残差比第 2 轮大，这说明残差并不单调下降，因为每轮的目标 $\hat{\mu}$ 都在变。

图 24.14比较这条轨迹与障碍法（$\tau = 0.2$）。两者起点相同，绿线直接朝解走，9 轮停止；黄线先走到 $\mu = 1$ 的碗底，再沿路径前进，在同样的精度下用了 34 个 Newton 步。图 24.15给出各残差随轮次的变化，可以看到 $\lVert r_{\mathrm{p}}\rVert_\infty$ 从零升起，这是约束弯曲带来的。

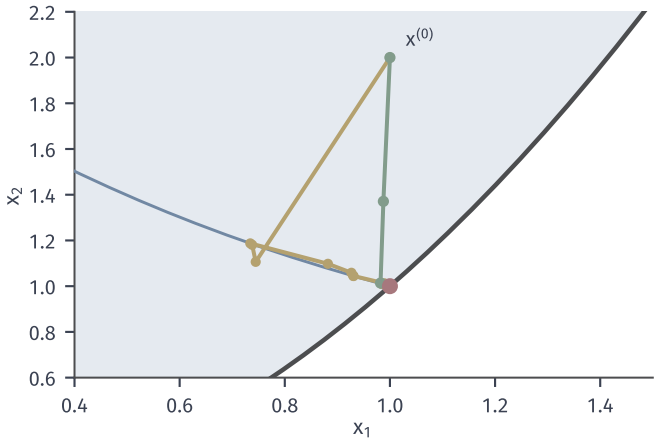


图 24.14　贯穿例的迭代点，局部放大。蓝线是中心路径，绿线是 $\sigma = 0.2$ 的原始—对偶迭代，黄线是 $\tau = 0.2$ 的障碍法的 Newton 迭代点，红点是 $\boldsymbol{x}^\star$，深灰粗线是约束边界。两者都从 $(1, 2)$ 出发。

24.1 障碍问题
24.2 原始—对偶内点法
24.3 初始化与精度
24.3.1 初始点的构造
24.3.2 停止条件
24.4 锥规划中的障碍
24.5 保证与计算成本
24.6 本章小结

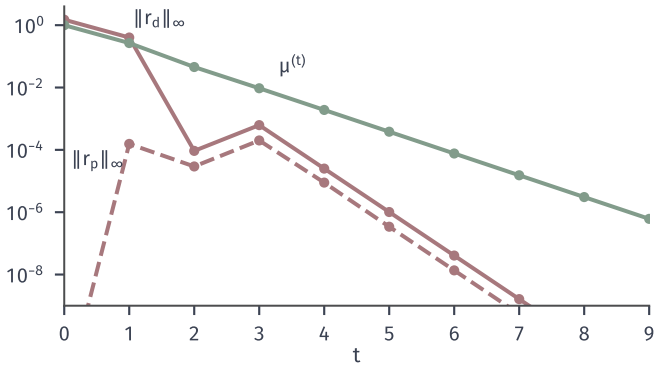


图 24.15 贯穿例的残差历史，对数纵轴。红色实线是 $\|\boldsymbol{r}_{\mathrm{d}}\|_\infty$，红色虚线是 $\|\boldsymbol{r}_{\mathrm{p}}\|_\infty$（第 0 轮为零，图中从下方进入），绿线是 $\mu^{(t)}$。

预测—校正要重新核对条件 第 4章的预测—校正可以直接搬用：先解 $\sigma = 0$ 的方程组，用试走后的互补量选 σ，再把 $\Delta s_i^{\mathrm{a}}\Delta\lambda_i^{\mathrm{a}}$ 移到右端。两次求解共用一次分解。例中第一轮，预测步的结果是

$$\alpha^{\mathrm{a}} \approx 0.7015, \qquad \mu^{\mathrm{a}} \approx 0.1640, \qquad \sigma \approx 0.0044.$$

校正后取到 $\alpha \approx 0.8556$，平均互补量降到 0.2085，而固定 $\sigma = 0.2$ 时是 0.2673。代价也很明显：两个乘积变成 0.0997 和 0.3174，不再相等。

搬用时有三点要重新核对。校正项只补偿了互补方程的二阶项，约束的二阶余项 $\boldsymbol{\rho}$ 并没有补偿。预测步用的 $\boldsymbol{W}$ 若经过了正则化，二阶项的估计就是另一个问题的量。线性规划中单位步之后等式残差恰好消失，这里没有这个性质，所以校正之后的步长仍要过残差或过滤器的检验，单靠比例规则不够。

24.3 初始化与精度

前两节都假设手里已经有一个能用的起点，也没有说算到什么程度可以停。本节要回答这两个问题：障碍路径和原始—对偶迭代分别需要怎样的起点，以及停下来的点能对原问题说什么。

24.3.1 初始点的构造

两类方法对起点的要求不同。障碍法要计算 $\log(-g_i(\boldsymbol{x}))$，所以每个迭代点都必须严格可行。原始—对偶方法的方程里不出现 $\log(-g_i)$，它只要求 $\boldsymbol{s},\boldsymbol{\lambda} > \boldsymbol{0}$，$\boldsymbol{x}$ 可以在可行域之外。

辅助可行性问题 需要严格可行点时，可以先解一个以“最大违反量”为目标的问题：

$$\min_{\boldsymbol{x},\rho} \ \rho \quad \text{s.t.} \quad g_i(\boldsymbol{x}) \le \rho \ (i=1,\dots,m), \quad \boldsymbol{h}(\boldsymbol{x}) = \boldsymbol{0}. \tag{24.32}$$

这个问题的严格可行点是现成的：只要有一个满足等式的 $\boldsymbol{x}$，取 $\rho > \max_i g_i(\boldsymbol{x})$ 即可。线性等式可以解线性方程组得到这样的 $\boldsymbol{x}$，非线性等式本身就是一个方程求根的问题，这里并没有绕过它。

设 $\rho^\star$ 是最优值。在凸问题上，它的符号给出三种结论：

- $\rho^\star < 0$：最优点严格可行，可以作为障碍法的起点。
- $\rho^\star = 0$：原问题可行或处在可行的边缘，但没有严格可行点。
- $\rho^\star > 0$：原问题不可行。

在非凸问题上，算法只能找到局部解，$\rho > 0$ 的局部解不能说明原问题不可行。

贯穿例从 $\boldsymbol{x}^{(0)} = (2,1)^{\mathsf{T}}$ 开始，$\boldsymbol{g} = (3,-3)^{\mathsf{T}}$，取 $\rho = 4$ 就严格可行。解 $\min \max\{x_1^2 - x_2,\ x_2 - 4\}$ 时，$x_1 = 0$ 使第一项最小，再让 $-x_2 = x_2 - 4$，得到

$$\boldsymbol{x} = (0,2)^{\mathsf{T}}, \qquad \rho^\star = -2.$$

这正是解析中心。图 24.16显示，随着 ρ 减小，放宽后的区域逐层收缩到这一点。实际上不必解到最优，一旦 $\rho < 0$ 就可以提前停下，这时得到的点已经是严格可行的。

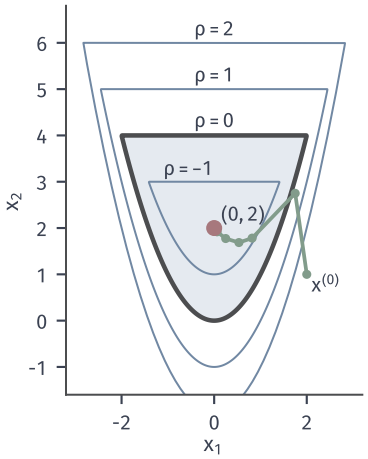


图 24.16 贯穿例的辅助问题 (24.32)。蓝线是 $\max_i g_i(\boldsymbol{x}) = \rho$ 的水平集，深灰粗线是 $\rho = 0$，即原可行集的边界。绿线是从可行域外的 $\boldsymbol{x}^{(0)} = (2,1)$ 出发、用障碍法解这个问题的迭代点，红点是解 $(0,2)$，这里 $\rho^\star = -2$。

从非零的原始残差开始 原始–对偶方法不用先解辅助问题。任取 $\boldsymbol{x}^{(0)}$，再选一个正的下限 δ，令

$$s_i^{(0)} = \max\{-g_i(\boldsymbol{x}^{(0)}),\ \delta\}, \qquad \lambda_i^{(0)} = \frac{\mu^{(0)}}{s_i^{(0)}}. \tag{24.33}$$

这样所有乘积都等于 $\mu^{(0)}$，起点在互补方程的意义下是居中的。约束已满足的分量，$\boldsymbol{r}_{\mathrm{p}}$ 是零，被违反的分量，$\boldsymbol{r}_{\mathrm{p}}$ 非零。

要记住的是，$\boldsymbol{s},\boldsymbol{\lambda} > \boldsymbol{0}$ 并不意味着 $\boldsymbol{g}(\boldsymbol{x}) + \boldsymbol{s} = \boldsymbol{0}$ 已经成立。正性是起点就满足的，松弛方程是迭代要逐步解的。在 $\boldsymbol{r}_{\mathrm{p}} \neq \boldsymbol{0}$ 的点上，$s_i > 0$ 也不告诉我们 $g_i(\boldsymbol{x}) < 0$。

贯穿例取 $\boldsymbol{x}^{(0)} = (2,1)^{\top}$，$\delta = 1$，$\mu^{(0)} = 1$，由式 (24.33)得到

$$\boldsymbol{s}^{(0)} = \begin{bmatrix} 1 \\ 3 \end{bmatrix}, \qquad \boldsymbol{\lambda}^{(0)} = \begin{bmatrix} 1 \\ 1/3 \end{bmatrix}, \qquad \boldsymbol{r}_{\mathrm{p}} = \begin{bmatrix} 4 \\ 0 \end{bmatrix}.$$

仍取 $\sigma = 0.2$，按式 (24.22)算出

$$\tilde{\boldsymbol{H}} = \begin{bmatrix} 19 & -4 \\ -4 & 19/9 \end{bmatrix}, \qquad \boldsymbol{b} \approx \begin{bmatrix} -15.8 \\ 3.133 \end{bmatrix}.$$

解出方向并回代，得到

$$\Delta\boldsymbol{x} \approx (-0.8636,\ -0.1521)^{\top}, \qquad \Delta\boldsymbol{s} \approx (-0.6977,\ 0.1521)^{\top}.$$

这一轮取到 $\alpha = 1$。线性规划中单位步会让等式残差归零，这里第一个分量却变成 $\Delta x_1^2 \approx 0.7458$，这就是图 24.10(b) 的右端点。

第二轮 $\alpha \approx 0.946$，$r_{\mathrm{p},1}$ 降到 0.059，再一轮之后降到 1.7×10^{-5}。图 24.17显示，残差下降虽然不再是精确的比例，但在这个例子上很快就跟上了互补量。

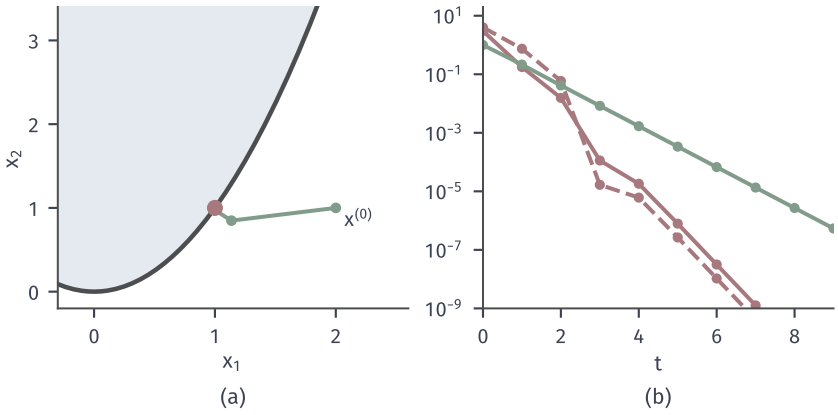


图 24.17 从可行域外启动，贯穿例，$\sigma = 0.2$、$\eta = 0.9$。(a) 绿线是迭代点，从 $(2,1)$ 进入可行域附近，红点是 $\boldsymbol{x}^\star$。(b) 红色虚线是 $\|\boldsymbol{r}_{\mathrm{p}}\|_\infty$，红色实线是 $\|\boldsymbol{r}_{\mathrm{d}}\|_\infty$，绿线是 $\mu^{(t)}$。

不收敛到可行点的情形 线性化的约束可能和当前的残差彼此矛盾。看不可行的一维约束 $g(x) = x^2 + 1 \le 0$。残差 $x^2 + 1 + s$ 在 $s > 0$ 上没有零点，迭代会被吸引到 $x = 0$、$s \to 0$，这一点上 $J = 2x = 0$，线性化的约束不再能改变残差。这是约束违反量的一个驻点，不是原问题的解。

对凸问题，这样的点可以变成证书。若存在 $\boldsymbol{w} \ge \boldsymbol{0}$，使 $\inf_{\boldsymbol{x}} \sum_i w_i g_i(\boldsymbol{x}) > 0$，则约束一定无解，因为可行点会让这个和不大于零。上面的例子取 $w = 1$，$\inf_x (x^2 + 1) = 1 > 0$。非凸问题没有这样的结论，算法停在不可行驻点时，只能报告“这一带没有找到可行点”。

缺少严格可行点或约束退化 内点法依赖的几个条件可能在模型层面就不成立，这时调参数没有用，要回到模型。图 24.18是三种常见情形。

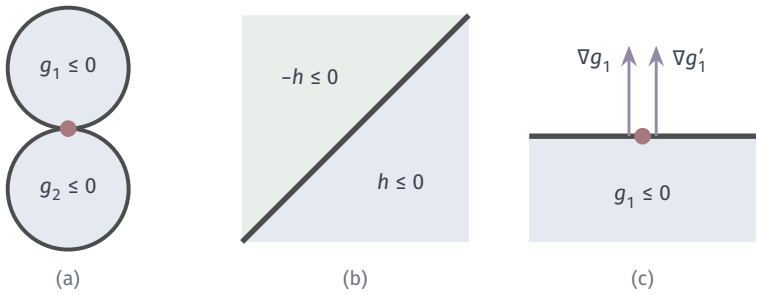
图 (a) 的约束是两个相切的圆盘：

$$x_1^2 + (x_2 - 1)^2 \le 1, \qquad x_1^2 + (x_2 + 1)^2 \le 1.$$

可行集只有原点，$\boldsymbol{C}^\circ$ 是空集。若目标是 $\min x_1$，原点是唯一的可行点，但 $\nabla f = (1,0)^{\mathsf{T}}$ 无法写成 $(0,-2)^{\mathsf{T}}$ 和 $(0,2)^{\mathsf{T}}$ 的组合，KKT 条件不成立。这时根本没有路径。

图 (b) 是把一条等式拆成两条不等式，内部同样是空的。这种情形只需把等式约束显式写出来。

图 (c) 是重复的约束，例如把 $g_1 \le 0$ 写了两遍。这时 $\boldsymbol{C}^\circ$ 不空，沿路径两个乘子相等，极限却不满足线性无关：在极限点，乘子的方向 $(1,-1)$ 落在 Newton 矩阵的零空间里，矩阵奇异。算法的表现是 $\boldsymbol{D}$ 很大的时候矩阵越来越病态，需要预处理去掉重复约束，或者加上 δ_{c}。



24.1 障碍问题
24.2 原始—对偶内点法
24.3 初始化与精度
24.3.1 初始点的构造
24.3.2 停止条件
24.4 锥规划中的障碍
24.5 保证与计算成本
24.6 本章小结

图 24.18 内点法的条件在模型层面失效的三种情形。(a) 两个相切的圆盘（浅蓝），可行集只有红点，没有内部。(b)$h \le 0$ 和 $-h \le 0$ 的公共部分是深灰的直线，同样没有内部。(c) 同一条约束写了两遍，紫色箭头是两个相同的梯度，它们线性相关，乘子不唯一。

24.3.2 停止条件

迭代点永远在内部，算法只能在某处停下。这一小节回答什么量决定停止，以及停下的点能保证什么。

三项分别评价 对参数 μ，定义误差

$$E_\mu(\boldsymbol{z}) = \max\left\{ \frac{\|\boldsymbol{r}_{\mathrm{d}}\|_\infty}{c_{\mathrm{d}}},\ \|\boldsymbol{r}_{\mathrm{e}}\|_\infty,\ \|\boldsymbol{r}_{\mathrm{p}}\|_\infty,\ \frac{\|\boldsymbol{S}\boldsymbol{\Lambda}\mathbf{1} - \mu\mathbf{1}\|_\infty}{c_{\mathrm{c}}} \right\}, \tag{24.34}$$

这里 $c_{\mathrm{d}}, c_{\mathrm{c}} \ge 1$ 是按乘子大小确定的缩放，防止乘子很大时要求过严，贯穿例中都取 1。E_μ 度量子问题的误差，E_0 才度量原问题的 KKT 误差。最后的判据是 $E_0 \le \varepsilon$。

参数小不等于解好了 一个很小的 μ 什么都说明不了，因为 μ 是算法自己设定的数。起点取 $\boldsymbol{\lambda} = 10^{-3}\mathbf{1}$，$\mu$ 立刻就很小，而 $\boldsymbol{r}_{\mathrm{d}}$ 的大小是 2。反过来，E_μ 很小也只说明子问题解得好。

图 24.19是贯穿例上的一次运行，每当 $E_\mu \le 0.1\mu$ 时，令 $\mu \leftarrow 0.2\mu$。第 6 轮 $E_\mu \approx 1.3 \times 10^{-5}$，子问题已经解得很准，而 $E_0 = 0.04$，正好是当时的 μ。可以看到 E_0 紧贴 μ 下降，E_μ 每次更新参数后跳起，再快速下降。

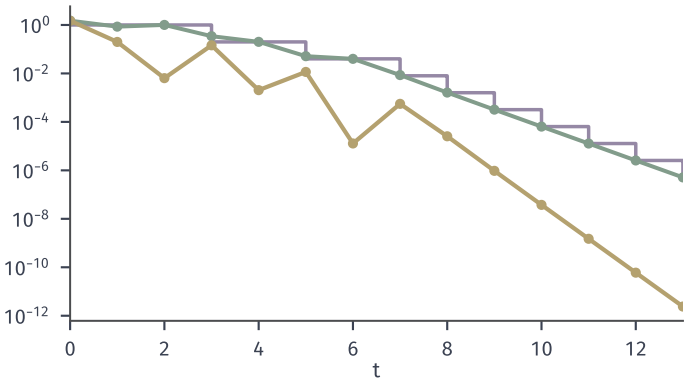


图 24.19 子问题误差与原问题误差，贯穿例，μ 只在 $E_\mu \le 0.1\mu$ 时按 0.2 倍减小，对数纵轴。紫色折线是当前的 μ，绿线是原问题的 KKT 误差 E_0，黄线是子问题误差 E_μ。E_μ 很小的时候，E_0 仍然停在 μ 的水平上。

内层精度与外层参数的配合 由定义，$|E_0 - E_\mu| \le \mu/c_{\mathrm{c}}$，所以把 E_μ 解得比 μ 小很多并没有好处，E_0 反正停在 μ 的量级。常用的规则是：内层解到 $E_\mu \le \kappa\mu$，再更新参数

$$\mu^{+} = \max\Big\{\frac{\varepsilon}{10},\ \min\{\tau\mu,\ \mu^{1+\theta}\}\Big\}, \tag{24.35}$$

其中 $\kappa > 0$，$\tau \in (0,1)$，$\theta \in (0,1)$。μ 大时线性减小，μ 小时超线性减小。下限 $\varepsilon/10$ 防止参数比容差小太多，否则 $\boldsymbol{D}$ 的数值徒然变大，矩阵更病态，而精度并不提高。

近似点能保证什么 下面的定理说明残差小怎样转化成目标误差，它把定理 24.4推广到迭代点不在路径上、残差不为零的情形。

定理 24.9 近似点的目标误差 设 f、g_i 凸且可微，$\boldsymbol{h}(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}$，$(\boldsymbol{x}, \boldsymbol{s}, \boldsymbol{\lambda}, \boldsymbol{\nu})$ 满足 $\boldsymbol{\lambda} \ge \boldsymbol{0}$，残差如式 (24.17)定义。设 $\boldsymbol{x}^\star$ 是最优解，$R \ge \|\boldsymbol{x} - \boldsymbol{x}^\star\|_2$。则

$$f(\boldsymbol{x}) - f^\star \le \boldsymbol{\lambda}^{\top}\boldsymbol{s} - \boldsymbol{\lambda}^{\top}\boldsymbol{r}_{\mathrm{p}} - \boldsymbol{\nu}^{\top}\boldsymbol{r}_{\mathrm{e}} + \|\boldsymbol{r}_{\mathrm{d}}\|_2 R. \tag{24.36}$$

若 $(\boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 是一组 KKT 乘子，则还有

$$f(\boldsymbol{x}) - f^\star \ge -(\boldsymbol{\lambda}^\star)^{\top}\boldsymbol{g}(\boldsymbol{x}) - (\boldsymbol{\nu}^\star)^{\top}\boldsymbol{r}_{\mathrm{e}}. \tag{24.37}$$

证明 由 $\boldsymbol{\lambda} \geq \mathbf{0}$ 和 $\boldsymbol{x}^\star$ 可行，有

$$f^\star \geq \mathcal{L}(\boldsymbol{x}^\star, \boldsymbol{\lambda}, \boldsymbol{\nu}).$$

函数 $\mathcal{L}(\cdot, \boldsymbol{\lambda}, \boldsymbol{\nu})$ 是凸的，在 $\boldsymbol{x}$ 处的梯度是 $\boldsymbol{r}_{\mathrm{d}}$，于是

$$\mathcal{L}(\boldsymbol{x}^\star, \boldsymbol{\lambda}, \boldsymbol{\nu}) \geq \mathcal{L}(\boldsymbol{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}) + \boldsymbol{r}_{\mathrm{d}}^{\top}(\boldsymbol{x}^\star - \boldsymbol{x}) \geq \mathcal{L}(\boldsymbol{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}) - \|\boldsymbol{r}_{\mathrm{d}}\|_2 R.$$

代入 $\boldsymbol{g}(\boldsymbol{x}) = \boldsymbol{r}_{\mathrm{p}} - \boldsymbol{s}$ 和 $\boldsymbol{h}(\boldsymbol{x}) = \boldsymbol{r}_{\mathrm{e}}$，$\mathcal{L}(\boldsymbol{x}, \boldsymbol{\lambda}, \boldsymbol{\nu})$ 展开为

$$f(\boldsymbol{x}) - \boldsymbol{\lambda}^{\top}\boldsymbol{s} + \boldsymbol{\lambda}^{\top}\boldsymbol{r}_{\mathrm{p}} + \boldsymbol{\nu}^{\top}\boldsymbol{r}_{\mathrm{e}}.$$

整理即得式 (24.36)。

对下界，$\boldsymbol{x}^\star$ 是凸函数 $\mathcal{L}(\cdot, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star)$ 的最小点，并且由互补，这个最小值等于 $f^\star$，于是

$$f^\star \leq \mathcal{L}(\boldsymbol{x}, \boldsymbol{\lambda}^\star, \boldsymbol{\nu}^\star) = f(\boldsymbol{x}) + (\boldsymbol{\lambda}^\star)^{\top}\boldsymbol{g}(\boldsymbol{x}) + (\boldsymbol{\nu}^\star)^{\top}\boldsymbol{h}(\boldsymbol{x}).$$

移项即得式 (24.37)。 ■

式 (24.36)右端的第一项是互补量，其余三项是残差被乘子和距离放大的部分。这正是第 4章不可行点上间隙公式的非线性版本。下界说明，点略微不可行时目标可以低于 $f^\star$，低的幅度由违反量乘以最优乘子决定。

用表 24.2中 $t = 4$ 的点核对。这时互补量和两个残差项是

$$\boldsymbol{\lambda}^{\top}\boldsymbol{s} \approx 3.82 \times 10^{-3}, \quad |\boldsymbol{\lambda}^{\top}\boldsymbol{r}_{\mathrm{p}}| \approx 8.9 \times 10^{-6}, \quad \|\boldsymbol{r}_{\mathrm{d}}\|_2 \approx 2.5 \times 10^{-5}.$$

可行集的直径不超过 4.5，取 $R = 4.5$，上界约为 3.92×10^{-3}。实际误差是 1.92×10^{-3}，确实在界内。

始终按原问题报告 内点法的内部变量经过松弛、缩放，矩阵可能经过正则化，交付时都要回到原问题上算一遍。可行性按 $\max_i \max\{g_i(\boldsymbol{x}), 0\}$ 和 $\|\boldsymbol{h}(\boldsymbol{x})\|_\infty$ 计算，而不是 $\|\boldsymbol{r}_{\mathrm{p}}\|_\infty$，因为 $s_i > 0$ 时残差小并不排除 $g_i(\boldsymbol{x})$ 略大于零。互补按 $\lambda_i |g_i(\boldsymbol{x})|$ 计算，驻定按未缩放的梯度计算。

三种常见的修改都可能制造假象。矩阵正则化只改变方向，不改变残差的定义，所以它本身不影响判据，但 δ_{c} 较大时迭代可能停在一个并不满足等式的点上。把约束放宽成 $g_i \leq \epsilon$ 的实现，要说明放宽量。恢复步骤之后乘子往往被重置，这时要用新的乘子重新计算 $\boldsymbol{r}_{\mathrm{d}}$，不能沿用恢复之前的数值。

24.1 障碍问题
24.2 原始—对偶内点法
24.3 初始化与精度
24.4 锥规划中的障碍
24.4.1 二阶锥障碍
24.4.2 半正定锥障碍
24.5 保证与计算成本
24.6 本章小结

收敛到一个 E_0 很小的点，在非凸问题上也只说明这一点近似满足 KKT 条件。若需要二阶信息，还要看最后一次分解时是否用过 $\delta_{\mathrm{w}} > 0$，用过说明约化 Hessian 在该点并不正定。

24.4 锥规划中的障碍

有些约束写成标量不等式并不自然。$\|\boldsymbol{u}\|_2 \le t$ 在 $\boldsymbol{u} = \mathbf{0}$ 处不可微，矩阵正定更是一个无法用有限条光滑不等式简单表达的条件。接下来要弄清：怎样为这些集合直接造一个障碍，路径跟踪的哪些操作可以照搬，哪些不能？

共同的框架 第 20章的锥规划写成

$$\min_{\boldsymbol{x}} \langle \boldsymbol{c}, \boldsymbol{x} \rangle \quad \text{s.t.} \quad \mathcal{A}\boldsymbol{x} = \boldsymbol{b}, \quad \boldsymbol{x} \in \boldsymbol{K}, \tag{24.38}$$

其中 $\boldsymbol{K}$ 是闭凸锥，$\mathcal{A}$ 是线性映射。它的对偶问题是

$$\max_{\boldsymbol{y},\boldsymbol{z}} \boldsymbol{b}^{\top}\boldsymbol{y} \quad \text{s.t.} \quad \mathcal{A}^{*}\boldsymbol{y} + \boldsymbol{z} = \boldsymbol{c}, \quad \boldsymbol{z} \in \boldsymbol{K}^{*}, \tag{24.39}$$

$\boldsymbol{K}^{*}$ 是对偶锥，$\mathcal{A}^{*}$ 是 $\mathcal{A}$ 的伴随映射，$\boldsymbol{z}$ 的角色就是第 4章的对偶松弛。可行点上目标差仍是 $\langle \boldsymbol{x}, \boldsymbol{z} \rangle$。

设 ϕ 是定义在 $\boldsymbol{K}$ 内部的障碍函数。障碍问题 $\min \langle \boldsymbol{c}, \boldsymbol{x} \rangle + \mu\phi(\boldsymbol{x})$ 的一阶条件给出 $\boldsymbol{c} + \mu\nabla\phi(\boldsymbol{x}) = \mathcal{A}^{*}\boldsymbol{y}$。令 $\boldsymbol{z} = \boldsymbol{c} - \mathcal{A}^{*}\boldsymbol{y}$，得到中心路径的方程

$$\mathcal{A}\boldsymbol{x} = \boldsymbol{b}, \qquad \mathcal{A}^{*}\boldsymbol{y} + \boldsymbol{z} = \boldsymbol{c}, \qquad \boldsymbol{z} = -\mu\nabla\phi(\boldsymbol{x}). \tag{24.40}$$

第三式就是互补方程的一般形式。取 $\phi = -\sum_i \log x_i$，它就是 $x_i z_i = \mu$。

间隙由障碍的一个性质决定。设 ϕ 满足 $\phi(\tau\boldsymbol{x}) = \phi(\boldsymbol{x}) - \vartheta \log\tau$，对所有 $\tau > 0$ 成立。对 τ 求导再令 $\tau = 1$，得到

$$\langle \nabla\phi(\boldsymbol{x}), \boldsymbol{x} \rangle = -\vartheta.$$

代入式 (24.40)，沿路径的间隙是

$$\langle \boldsymbol{x}, \boldsymbol{z} \rangle = \vartheta\mu. \tag{24.41}$$

数 ϑ 称为**障碍参数**（barrier parameter），它取代了线性规划中的 n 和本章前面的 m。

24.4.1 二阶锥障碍

记 $\boldsymbol{x} = (\boldsymbol{u}, t)$，$\boldsymbol{u} \in \mathbb{R}^{q}$，$t \in \mathbb{R}$，第 20章的二阶锥是 $\{(\boldsymbol{u}, t) : \|\boldsymbol{u}\|_2 \le t\}$。它的内部由 $t > \|\boldsymbol{u}\|_2$ 给出，等价于 $t > 0$ 且 $t^2 - \|\boldsymbol{u}\|_2^2 > 0$。

定义 24.10　二阶锥障碍　记 $\boldsymbol{R}=\operatorname{diag}(-\boldsymbol{I}_q,1)$，$\omega(\boldsymbol{x})=\boldsymbol{x}^{\top}\boldsymbol{R}\boldsymbol{x}$。在二阶锥内部定义

$$\phi(\boldsymbol{x})=-\log\omega(\boldsymbol{x})=-\log\bigl(t^2-\|\boldsymbol{u}\|_2^2\bigr). \tag{24.42}$$

点靠近锥面时 $\omega\downarrow 0$，$\phi\to+\infty$，一整张锥面只用一项对数表达。由 $\omega(\tau\boldsymbol{x})=\tau^2\omega(\boldsymbol{x})$，这个障碍的参数是 $\vartheta=2$，与维数 q 无关。

导数　由 $\nabla\omega=2\boldsymbol{R}\boldsymbol{x}$、$\nabla^2\omega=2\boldsymbol{R}$ 和复合函数法则，得到

$$\nabla\phi(\boldsymbol{x})=-\frac{2\boldsymbol{R}\boldsymbol{x}}{\omega},\qquad \nabla^2\phi(\boldsymbol{x})=\frac{4\boldsymbol{R}\boldsymbol{x}\boldsymbol{x}^{\top}\boldsymbol{R}}{\omega^2}-\frac{2\boldsymbol{R}}{\omega}. \tag{24.43}$$

$\boldsymbol{R}$ 不定，所以第二项不定，正定性要靠两项配合。

引理 24.11　二阶锥障碍的 Hessian 正定　在二阶锥内部，$\nabla^2\phi(\boldsymbol{x})\succ\boldsymbol{0}$。

证明　取非零的 $\boldsymbol{d}=(\boldsymbol{v},r)$。考察二次函数

$$p(\beta)=(\boldsymbol{d}+\beta\boldsymbol{x})^{\top}\boldsymbol{R}(\boldsymbol{d}+\beta\boldsymbol{x})=\omega\beta^2+2\beta\,\boldsymbol{x}^{\top}\boldsymbol{R}\boldsymbol{d}+\boldsymbol{d}^{\top}\boldsymbol{R}\boldsymbol{d}.$$

取 $\beta_0=-r/t$，向量 $\boldsymbol{d}+\beta_0\boldsymbol{x}$ 的最后一个分量为零，所以

$$p(\beta_0)=-\|\boldsymbol{v}+\beta_0\boldsymbol{u}\|_2^2\le 0.$$

又 $\omega>0$，所以 p 有实根，判别式非负，这就是

$$(\boldsymbol{x}^{\top}\boldsymbol{R}\boldsymbol{d})^2\ge\omega\,\boldsymbol{d}^{\top}\boldsymbol{R}\boldsymbol{d}.$$

由式 (24.43)，Hessian 的二次型是

$$\boldsymbol{d}^{\top}\nabla^2\phi\,\boldsymbol{d}=\frac{4(\boldsymbol{x}^{\top}\boldsymbol{R}\boldsymbol{d})^2}{\omega^2}-\frac{2\boldsymbol{d}^{\top}\boldsymbol{R}\boldsymbol{d}}{\omega}.$$

若 $\boldsymbol{d}^{\top}\boldsymbol{R}\boldsymbol{d}>0$，代入判别式不等式，它不小于 $2\boldsymbol{d}^{\top}\boldsymbol{R}\boldsymbol{d}/\omega>0$。

若 $\boldsymbol{d}^{\top}\boldsymbol{R}\boldsymbol{d}\le 0$，两项都非负。两项同时为零时，$\boldsymbol{d}^{\top}\boldsymbol{R}\boldsymbol{d}=0$ 且 $\boldsymbol{x}^{\top}\boldsymbol{R}\boldsymbol{d}=0$，于是

$$p(\beta)=\omega\beta^2.$$

结合 $p(\beta_0)\le 0$，得 $\beta_0=0$，即 $r=0$。这时 $p(\beta_0)=0$ 给出 $\boldsymbol{v}=\boldsymbol{0}$，与 $\boldsymbol{d}\neq\boldsymbol{0}$ 矛盾。 ∎

用一个二维的点核对，取 $q=1$，$\boldsymbol{x}=(u,t)=(1,2)$，这时 $\omega=3$。由式 (24.43)，

$$\nabla\phi=\begin{bmatrix}2/3\\-4/3\end{bmatrix},\qquad \nabla^2\phi=\frac{1}{9}\begin{bmatrix}10&-8\\-8&10\end{bmatrix}.$$

Hessian 的特征值是 $2/9$ 和 2，都是正的。

允许的步长 沿方向 $\boldsymbol{d}=(\boldsymbol{v},r)$ 走到 $\boldsymbol{x}+\alpha\boldsymbol{d}$，$\omega$ 是 α 的二次函数：

$$\omega(\alpha)=\omega+2\alpha\,\boldsymbol{x}^{\top}\boldsymbol{R}\boldsymbol{d}+\alpha^2\,\boldsymbol{d}^{\top}\boldsymbol{R}\boldsymbol{d}. \tag{24.44}$$

$\alpha_{\max}$ 是使 $t+\alpha r>0$ 的前提下 $\omega(\alpha)$ 的最小正根。这和线性规划的比值检验是同一件事，只是一次方程换成了二次方程，仍然有精确的公式，不需要试探。

例中取 $\boldsymbol{d}=(2,-1)$，式 (24.44)给出

$$\omega(\alpha)=3-8\alpha-3\alpha^2=(1-3\alpha)(3+\alpha).$$

最小正根是 $\alpha_{\max}=1/3$，对应锥面上的点 $(5/3,5/3)$。沿这条线，ϕ 的两个导数是 $8/3$ 和 $82/9$，图 24.20(b) 的黄线就是这个二次模型，它在边界处仍是有限值，真正的障碍趋于无穷。

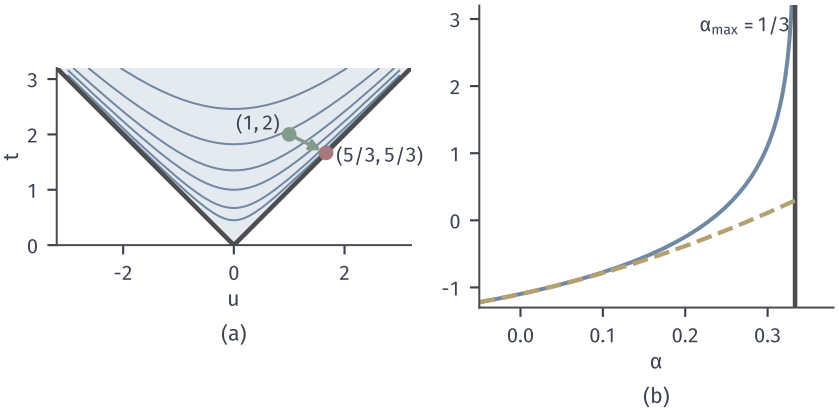


图 24.20 二阶锥（$q=1$）的障碍。(a) 浅蓝区域是锥内部，深灰粗线是锥面，蓝线是 ϕ 的等值线。绿点是 $(1,2)$，绿色箭头是方向 $(2,-1)$，红点是它到达锥面的位置 $(5/3,5/3)$。(b) 沿该方向的 ϕ（蓝线）与它在 $\alpha=0$ 处的二次模型（黄色虚线），深灰粗线是 $\alpha_{\max}=1/3$。

仿射映射进入锥后的 Newton 系统 实际问题的约束通常写成

$$\|\boldsymbol{B}\boldsymbol{x}+\boldsymbol{e}\|_2\le\boldsymbol{a}^{\top}\boldsymbol{x}+d,$$

24.1 障碍问题
24.2 原始—对偶内点法
24.3 初始化与精度
24.4 锥规划中的障碍
24.4.1 二阶锥障碍
24.4.2 半正定锥障碍
24.5 保证与计算成本
24.6 本章小结

也就是 $\boldsymbol{y}(\boldsymbol{x}) = \boldsymbol{Q}\boldsymbol{x} + \boldsymbol{q}$ 落在锥中，这里 $\boldsymbol{Q}$ 由 $\boldsymbol{B}$ 和 $\boldsymbol{a}^{\mathsf{T}}$ 拼成，$\boldsymbol{q} = (\boldsymbol{e}, d)$。由链式法则，

$$\nabla_{\boldsymbol{x}}\phi = \boldsymbol{Q}^{\mathsf{T}}\nabla\phi(\boldsymbol{y}), \qquad \nabla^2_{\boldsymbol{x}}\phi = \boldsymbol{Q}^{\mathsf{T}}\nabla^2\phi(\boldsymbol{y})\boldsymbol{Q}. \tag{24.45}$$

把式 (24.43)代入，得到的矩阵是“稀疏的 $\boldsymbol{Q}^{\mathsf{T}}\boldsymbol{R}\boldsymbol{Q}$”加上一个秩一矩阵。秩一项的向量 $\boldsymbol{Q}^{\mathsf{T}}\boldsymbol{R}\boldsymbol{y}$ 通常是稠密的，直接相加会填满矩阵。保留锥结构的实现把它单独存放，或者在鞍点矩阵中增加一行一列，这样既不丢失稀疏性，也能用现成的分解。

展开成标量约束的代价 也可以把约束写成标量不等式 $g(\boldsymbol{u}, t) = \|\boldsymbol{u}\|_2 - t \le 0$，用本章前几节的方法。问题出在 $\boldsymbol{u} = \boldsymbol{0}$：$g$ 在这里不可微，而这恰恰可能是解所在的位置，例如目标要把 $\|\boldsymbol{B}\boldsymbol{x} + \boldsymbol{e}\|_2$ 压到零时。图 24.21显示，$-\log(t - \|\boldsymbol{u}\|_2)$ 在 $\boldsymbol{u} = \boldsymbol{0}$ 处有折角，$-\log(t^2 - \|\boldsymbol{u}\|_2^2)$ 却是光滑的，因为它用平方把折角消掉了。

改写成 $g = \|\boldsymbol{u}\|_2^2 - t^2 \le 0$ 并不解决问题。这个 g 不是凸函数，它的零下水平集还包括 $t < 0$ 的另一半锥，所以必须同时约束 $t \ge 0$。二阶锥障碍用 ω 的同时把定义域限定在 $t > 0$ 的内部，避免了这两个麻烦。

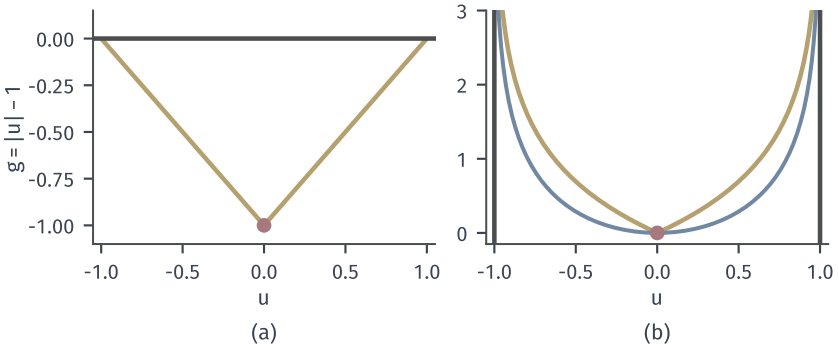


图 24.21 标量写法与锥障碍，$t = 1$。(a) 标量约束 $g = |u| - 1$ 在 $u = 0$ 处有折角（红点）。(b) 黄线是 $-\log(1 - |u|)$，保留了折角；蓝线是二阶锥障碍 $-\log(1 - u^2)$，在 $u = 0$ 处光滑。深灰粗线是边界。

24.4.2 半正定锥障碍

变量换成对称矩阵 $\boldsymbol{X} \in \mathcal{S}^n$，约束是 $\boldsymbol{X} \succeq \boldsymbol{0}$，内积是迹内积

$$\langle \boldsymbol{X}, \boldsymbol{Z} \rangle = \operatorname{tr}(\boldsymbol{X}\boldsymbol{Z}).$$

半正定锥在这个内积下是自对偶的，所以 $\boldsymbol{K}^* = \boldsymbol{K}$。

特征值逼近零　$\boldsymbol{X}$ 越靠近边界，最小的特征值越接近零。记 $\boldsymbol{X}$ 的特征值为 $\rho_1, \dots, \rho_n > 0$，对每个特征值都放一项对数障碍，得到

$$\phi(\boldsymbol{X}) = -\sum_{i=1}^{n} \log \rho_i(\boldsymbol{X}) = -\log\det \boldsymbol{X}. \tag{24.46}$$

计算时不必求特征值，$\log\det$ 可以由 Cholesky 分解得到。由 $\det(\tau \boldsymbol{X}) = \tau^n \det \boldsymbol{X}$，障碍参数是 $\vartheta = n$。

线性扰动下的导数　沿对称方向 $\boldsymbol{D}$ 看。因为 $\boldsymbol{X} \succ \boldsymbol{0}$，可以写成

$$\boldsymbol{X} + \alpha \boldsymbol{D} = \boldsymbol{X}^{1/2}\big(\boldsymbol{I} + \alpha \boldsymbol{X}^{-1/2} \boldsymbol{D} \boldsymbol{X}^{-1/2}\big)\boldsymbol{X}^{1/2}.$$

记 $\boldsymbol{X}^{-1/2}\boldsymbol{D}\boldsymbol{X}^{-1/2}$ 的特征值为 $\beta_1, \dots, \beta_n$，它们也是 $\boldsymbol{X}^{-1}\boldsymbol{D}$ 的特征值。取行列式再取对数，得到

$$\phi(\boldsymbol{X} + \alpha \boldsymbol{D}) = \phi(\boldsymbol{X}) - \sum_{i=1}^{n} \log(1 + \alpha \beta_i). \tag{24.47}$$

对 α 展开到二阶，一阶系数是 $-\sum_i \beta_i$，二阶系数是 $\sum_i \beta_i^2$。写成迹，就是

$$\begin{aligned} \langle \nabla \phi(\boldsymbol{X}), \boldsymbol{D} \rangle &= -\operatorname{tr}(\boldsymbol{X}^{-1}\boldsymbol{D}), \\ \langle \boldsymbol{D}, \nabla^2 \phi(\boldsymbol{X})[\boldsymbol{D}] \rangle &= \operatorname{tr}(\boldsymbol{X}^{-1}\boldsymbol{D}\boldsymbol{X}^{-1}\boldsymbol{D}). \end{aligned} \tag{24.48}$$

所以在迹内积下 $\nabla \phi(\boldsymbol{X}) = -\boldsymbol{X}^{-1}$，Hessian 是线性算子 $\boldsymbol{D} \mapsto \boldsymbol{X}^{-1}\boldsymbol{D}\boldsymbol{X}^{-1}$。

式 (24.47)同时给出最大步长。$\boldsymbol{X} + \alpha \boldsymbol{D} \succ \boldsymbol{0}$ 当且仅当每个 $1 + \alpha\beta_i > 0$，所以若 $\beta_{\min} < 0$，

$$\alpha_{\max} = -\frac{1}{\beta_{\min}}, \tag{24.49}$$

否则 $\alpha_{\max} = +\infty$。

用具体的矩阵算一遍。取

$$\boldsymbol{X} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \qquad \boldsymbol{D} = \begin{bmatrix} -1 & -1 \\ -1 & -2 \end{bmatrix}.$$

$\boldsymbol{X}$ 的特征值是 1 和 3。直接计算，

$$\boldsymbol{X}^{-1}\boldsymbol{D} = \frac{1}{3}\begin{bmatrix} -1 & 0 \\ -1 & -3 \end{bmatrix},$$

它的特征值是 $-1/3$ 和 -1，所以 $\alpha_{\max} = 1$。可以核对，$\boldsymbol{X} + \boldsymbol{D}$ 的第二行是零，确实落在边界上。

由式 (24.48)，一阶、二阶导数分别是

$$\frac{1}{3}+1=\frac{4}{3},\qquad \frac{1}{9}+1=\frac{10}{9}.$$

而 $\det(\boldsymbol{X}+\alpha\boldsymbol{D})=(1-\alpha)(3-\alpha)$，对 $-\log$ 直接求导得到同样的数。图 24.22显示了特征值沿这个方向的变化和障碍的上升。

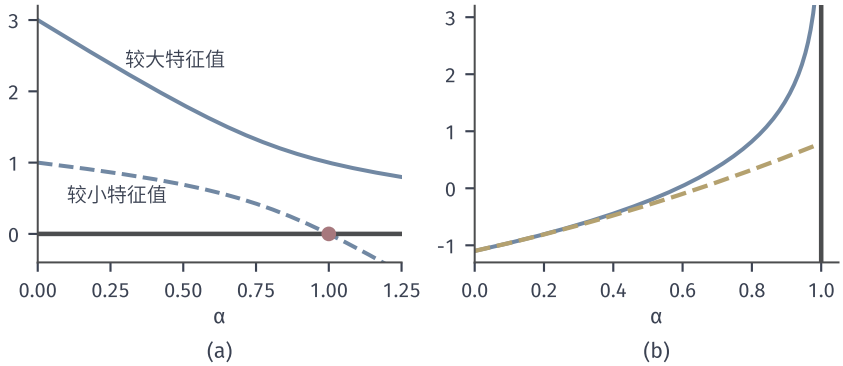


图 24.22　半正定锥的障碍，沿 $\boldsymbol{X}+\alpha\boldsymbol{D}$。(a)$\boldsymbol{X}+\alpha\boldsymbol{D}$ 的两个特征值，红点是较小的特征值到达零的位置 $\alpha_{\max}=1$，深灰粗线是零。(b) 蓝线是 $-\log\det(\boldsymbol{X}+\alpha\boldsymbol{D})$，黄色虚线是它在 $\alpha=0$ 处的二次模型，深灰粗线是 $\alpha_{\max}$。

矩阵的互补不能照搬标量操作　中心路径的第三式是 $\boldsymbol{Z}=\mu\boldsymbol{X}^{-1}$，等价于 $\boldsymbol{X}\boldsymbol{Z}=\mu\boldsymbol{I}$。标量情形下，线性化 $x_is_i=\mu$ 毫无歧义。矩阵情形下，直接线性化得到

$$\Delta\boldsymbol{X}\,\boldsymbol{Z}+\boldsymbol{X}\Delta\boldsymbol{Z}=\sigma\mu\boldsymbol{I}-\boldsymbol{X}\boldsymbol{Z}. \tag{24.50}$$

麻烦在于 $\boldsymbol{X}$ 和 $\boldsymbol{Z}$ 不交换，$\boldsymbol{X}\boldsymbol{Z}$ 一般不对称。解出来的 $\Delta\boldsymbol{X}$ 也不对称，走一步之后 $\boldsymbol{X}$ 就离开了对称矩阵空间。

看一个具体的例子。取前面的 $\boldsymbol{X}$，再取 $\boldsymbol{Z}=\operatorname{diag}(1,2)$，对偶方向 $\Delta\boldsymbol{Z}$ 是非对角的对称矩阵。由式 (24.50)解 $\Delta\boldsymbol{X}$ 时，出现的项是

$$\boldsymbol{X}\Delta\boldsymbol{Z}\boldsymbol{Z}^{-1}=\begin{bmatrix}2&1\\1&2\end{bmatrix}\begin{bmatrix}0&1\\1&0\end{bmatrix}\begin{bmatrix}1&0\\0&1/2\end{bmatrix}=\begin{bmatrix}1&1\\2&1/2\end{bmatrix},$$

它不是对称的。

解决的办法是**原始—对偶缩放**（primal-dual scaling）：选一个可逆矩阵 $\boldsymbol{P}$，不线性化 $\boldsymbol{X}\boldsymbol{Z}$，而线性化对称化之后的量

$$\mathcal{H}_{\boldsymbol{P}}(\boldsymbol{M})=\tfrac{1}{2}\big(\boldsymbol{P}\boldsymbol{M}\boldsymbol{P}^{-1}+(\boldsymbol{P}\boldsymbol{M}\boldsymbol{P}^{-1})^{\mathsf{T}}\big),\qquad \mathcal{H}_{\boldsymbol{P}}(\boldsymbol{X}\boldsymbol{Z})=\mu\boldsymbol{I}. \tag{24.51}$$

三种选择最常见：$\boldsymbol{P}=\boldsymbol{I}$ 只把结果对称化；$\boldsymbol{P}=\boldsymbol{Z}^{1/2}$ 称为 HKM 方向；$\boldsymbol{P}$ 取 Nesterov—Todd 缩放矩阵时，$\boldsymbol{X}$ 与 $\boldsymbol{Z}$ 被映到同一个矩阵。不同选择的方向不同，都要保证 $\Delta\boldsymbol{X}$、$\Delta\boldsymbol{Z}$ 是对称的。

24.1 障碍问题
24.2 原始—对偶内点法
24.3 初始化与精度
24.4 锥规划中的障碍
24.5 保证与计算成本
24.6 本章小结

以 HKM 方向为例，把 $\Delta \boldsymbol{X}$ 对称化之后，得到

$$\Delta \boldsymbol{X} = \sigma \mu \boldsymbol{Z}^{-1} - \boldsymbol{X} - \tfrac{1}{2}\big(\boldsymbol{X}\Delta\boldsymbol{Z}\boldsymbol{Z}^{-1} + \boldsymbol{Z}^{-1}\Delta\boldsymbol{Z}\boldsymbol{X}\big).$$

代入约束，形成关于 $\Delta \boldsymbol{y}$ 的方程，系数矩阵的元素是

$$M_{ij} = \operatorname{tr}\big(\boldsymbol{A}_i \boldsymbol{X} \boldsymbol{A}_j \boldsymbol{Z}^{-1}\big), \tag{24.52}$$

其中 $\boldsymbol{A}_i$ 是约束 $\langle \boldsymbol{A}_i, \boldsymbol{X}\rangle = b_i$ 的系数矩阵。它是第 4章 $\boldsymbol{A}\boldsymbol{D}\boldsymbol{A}^{\mathsf{T}}$ 的矩阵版本。

内积配对要保持一致 实现中常把对称矩阵排成向量，这一步很容易出错。$\boldsymbol{X}$ 有 $n(n+1)/2$ 个独立元素，若直接取上三角排成向量，内积就变了。前面的 $\boldsymbol{X}$ 满足 $\operatorname{tr}(\boldsymbol{X}^2) = 10$，而向量 $(2,1,2)$ 的平方和是 9，因为非对角元在迹里算了两次。

正确的做法是把非对角元乘以 $\sqrt{2}$，得到 $(2,\sqrt{2},2)$，平方和正好是 10。对偶变量、梯度和 $\mathcal{A}^*$ 都要用同样的约定，否则对偶可行性和间隙算的都不是原来的量。

三种障碍的对比 表 24.3把本章的三种障碍放在一起。形式相同的地方是路径和间隙的公式，不同的地方在互补的写法和步长的求法，这两处决定了线性代数的结构。

量	标量 $s>0$	二阶锥	半正定锥
障碍	$-\log s$	$-\log(t^2 - \lVert \boldsymbol{u}\rVert_2^2)$	$-\log\det \boldsymbol{X}$
参数 ϑ	1	2	n
$-\nabla\phi$	$1/s$	$2\boldsymbol{R}\boldsymbol{x}/\omega$	$\boldsymbol{X}^{-1}$
内积	乘法	欧氏内积	迹内积
$\alpha_{\max}$	比值	二次方程的根	$\boldsymbol{X}^{-1}\boldsymbol{D}$ 的特征值
线性代数	对角	对角加秩一	稠密缩放矩阵

表 24.3 三种锥的障碍及相应的计算。

24.5 保证与计算成本

第 4章证明了线性规划上短步路径跟踪的迭代界。这就需要回答：这个结果在什么条件下能够推广，在什么情形下必须退回局部结论，以及每一轮实际要花多少计算？

为什么要有一个比光滑更强的条件 Newton 法的通常分析用 Hessian 的 Lipschitz 常数 M，结论依赖坐标的选取。障碍函数在边界附近的三阶导数趋于无穷，M 根本不存在一个有限的整体值。路径跟踪的分析需要一种随点变化的尺子。

用 ϕ 自己的 Hessian 当尺子。下面的条件要求三阶导数被二阶导数控制，这就是**自协调**（self-concordant）。

定义 24.12　自协调障碍　设 ϕ 是开凸集上三阶连续可微的凸函数，在边界附近趋于 $+\infty$。记 ϕ'、ϕ''、ϕ''' 为沿方向 $\boldsymbol{d}$ 的方向导数。若对所有点和所有方向，

$$|\phi'''| \le 2(\phi'')^{3/2}, \qquad (\phi')^2 \le \vartheta\,\phi'', \tag{24.53}$$

就称 ϕ 是参数为 ϑ 的自协调障碍。

对 $\phi(x) = -\log x$，沿 $d = 1$ 的三个导数是 $-1/x$、$1/x^2$、$-2/x^3$。代入两个不等式，都恰好取等号，其中 $\vartheta = 1$。第一个不等式的两边在缩放 x 时变化相同，所以这个条件不依赖坐标的单位。

三种基本的障碍都是自协调的：m 条线性约束的对数障碍参数是 m，二阶锥障碍参数是 2，$n \times n$ 半正定锥障碍参数是 n。凸二次约束的 $-\log(-g)$ 也是自协调的，参数是 1，所以贯穿例的障碍参数是 $\vartheta = 2$。

Dikin 椭球：局部模型信多远　自协调的直接后果是，以 $\nabla^2\phi$ 定义的单位椭球落在定义域内：

$$\{\boldsymbol{x} + \boldsymbol{d} : \boldsymbol{d}^{\top}\nabla^2\phi(\boldsymbol{x})\boldsymbol{d} < 1\} \subset \operatorname{dom}\phi. \tag{24.54}$$

这个集合称为Dikin 椭球（Dikin ellipsoid）。多面体的情形可以直接验证：$\boldsymbol{g}(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}$ 时，二次型等于 $\sum_i (\boldsymbol{a}_i^{\top}\boldsymbol{d}/s_i)^2$。它小于 1，就有每个 $|\boldsymbol{a}_i^{\top}\boldsymbol{d}| < s_i$，于是新点的每个松弛都还是正的。

一般情形的证明需要沿线段积分第一个不等式，读者可查阅专著[2]。

图 24.23画出贯穿例的四个 Dikin 椭球，在椭球边界上逐点计算，松弛都是正的。靠近边界时椭球在法向变扁，在切向仍然较长。这就是局部模型“信多远”的答案，随位置自动调整，不需要知道全局的光滑常数。

[2] S. Boyd, L. Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004

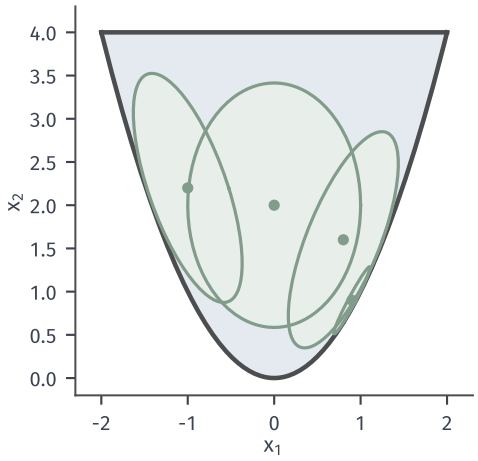


图 24.23 贯穿例的 Dikin 椭球，绿点是四个基点，绿色曲线是 $\boldsymbol{d}^{\mathsf{T}}\nabla^2\phi(\boldsymbol{x})\boldsymbol{d}=1$ 围成的椭球。四个椭球都留在可行集（浅蓝）之内，靠近边界的椭球更扁。

凸问题的迭代界 有了这把尺子，第 4章的短步分析可以整体推广，其中 $\sqrt{n}$ 换成 $\sqrt{\vartheta}$。结论如下，证明要用到自协调函数的 Newton 减量分析，篇幅较长，读者可查阅专著[3]。

[3] S. Boyd, L. Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004

定理 24.13 路径跟踪的迭代次数 设目标是线性函数，可行集有界且有严格可行点，ϕ 是参数为 ϑ 的自协调障碍，起点足够靠近路径。则短步路径跟踪得到 ε 精度的解所需的 Newton 步数为

$$O\Big(\sqrt{\vartheta}\,\log\frac{\vartheta\mu^{(0)}}{\varepsilon}\Big). \tag{24.55}$$

这个界不依赖 f 和 g_i 的条件数，只依赖 ϑ，这是内点法在凸问题上最强的结论。目标非线性时，可以用上图形式把它移进约束，代价是要为新的约束找到自协调障碍。

式 (24.55)也解释了为什么锥结构有价值。一个 $q+1$ 维的二阶锥只贡献 $\vartheta=2$，如果把它拆成很多线性不等式去逼近，ϑ 就随拆分的条数增长。

线性规划的结论不能外推 多项式界依赖两件事：约束有容易计算的自协调障碍，并且问题是凸的。两者都可能不成立。

第一，凸性并不自动给出自协调。取 $g(x)=\mathrm{e}^{x}-1\le 0$，障碍 $\phi=-\log(1-\mathrm{e}^{x})$ 是凸函数，但 $x\to-\infty$ 时 ϕ'' 和 ϕ''' 都约等于 e^{x}，于是

$$\frac{|\phi'''|}{(\phi'')^{3/2}}\approx \mathrm{e}^{-x/2}\to\infty.$$

第一个不等式不可能成立。每个开凸集都存在参数为 $O(n)$ 的自协调障碍，但这是存在性的结果，这样的障碍一般无法计算。

第二，非凸问题求全局解是 NP 难的，非凸二次规划就已经如此，所以不可能有类似式 (24.55)的全局结果，除非 P = NP。

非凸问题的局部收敛 非凸问题上能证明的是：在定理 24.5的条件下，从足够近的点出发，Newton 迭代跟着路径收敛到 KKT 点。下面给出一步的估计。记 $\boldsymbol{z}^\star$ 为该 KKT 点及其松弛、乘子，$\boldsymbol{F}_\mu(\boldsymbol{z}) = \boldsymbol{F}_0(\boldsymbol{z}) - \mu \boldsymbol{e}$，其中 $\boldsymbol{e}$ 只在互补方程处为 1，$\boldsymbol{G}$ 是 $\boldsymbol{F}_0$ 的 Jacobian 矩阵。

定理 24.14 Newton 步的局部估计 设定理 24.5的条件成立，$\nabla^2 f$、$\nabla^2 g_i$、$\nabla^2 h_j$ 在 $\boldsymbol{x}^\star$ 附近是 M-Lipschitz 的。则存在 $\boldsymbol{z}^\star$ 的邻域和常数 C_{G}、M_{G}、C_{p}（M_{G} 由 M 和乘子的界决定），使邻域内的 $\boldsymbol{z}$ 和足够小的 $\mu^+ > 0$ 满足：单位 Newton 步

$$\boldsymbol{z}^+ = \boldsymbol{z} - \boldsymbol{G}(\boldsymbol{z})^{-1} \boldsymbol{F}_{\mu^+}(\boldsymbol{z}) \tag{24.56}$$

有

$$\|\boldsymbol{z}^+ - \boldsymbol{z}^\star\|_2 \le \frac{C_{\mathrm{G}} M_{\mathrm{G}}}{2} \left(\|\boldsymbol{z} - \boldsymbol{z}^\star\|_2 + C_{\mathrm{p}} \mu^+ \right)^2 + C_{\mathrm{p}} \mu^+ . \tag{24.57}$$

证明 定理 24.5的证明说明 $\boldsymbol{G}(\boldsymbol{z}^\star)$ 非奇异，所以在邻域内

$$\|\boldsymbol{G}(\boldsymbol{z})^{-1}\|_2 \le C_{\mathrm{G}}.$$

$\boldsymbol{G}$ 的各块由 ∇f、$\nabla^2 f$、$\nabla^2 g_i$、$\nabla^2 h_j$ 和乘子组成，因此在邻域内是 M_{G}-Lipschitz 的。路径连续可微，所以

$$\|\boldsymbol{z}(\mu) - \boldsymbol{z}^\star\|_2 \le C_{\mathrm{p}} \mu.$$

记 $\boldsymbol{z}' = \boldsymbol{z}(\mu^+)$，它满足 $\boldsymbol{F}_{\mu^+}(\boldsymbol{z}') = \boldsymbol{0}$。由 Newton 步的定义，

$$\boldsymbol{z}^+ - \boldsymbol{z}' = \boldsymbol{G}(\boldsymbol{z})^{-1} \Big[\boldsymbol{G}(\boldsymbol{z})(\boldsymbol{z} - \boldsymbol{z}') - \big(\boldsymbol{F}_{\mu^+}(\boldsymbol{z}) - \boldsymbol{F}_{\mu^+}(\boldsymbol{z}') \big) \Big].$$

方括号内是一阶 Taylor 余项，由 $\boldsymbol{G}$ 的 Lipschitz 性，它的范数不超过 $\frac{1}{2} M_{\mathrm{G}} \|\boldsymbol{z} - \boldsymbol{z}'\|_2^2$。于是

$$\|\boldsymbol{z}^+ - \boldsymbol{z}'\|_2 \le \tfrac{1}{2} C_{\mathrm{G}} M_{\mathrm{G}} \|\boldsymbol{z} - \boldsymbol{z}'\|_2^2 .$$

由三角不等式，$\boldsymbol{z}$ 到 $\boldsymbol{z}'$ 的距离满足

$$\|\boldsymbol{z} - \boldsymbol{z}'\|_2 \le \|\boldsymbol{z} - \boldsymbol{z}^\star\|_2 + C_{\mathrm{p}} \mu^+ .$$

再对 $\boldsymbol{z}^+$ 用一次三角不等式，即得结论。 ■

式 (24.57)右端有两项：Newton 法自身的二次项，以及目标参数的偏移。μ^+ 与当前误差同阶时，收敛是线性的，表 24.2中 σ 固定为 0.2，误差每轮大约乘以 0.2，就是这种情形。按式 (24.35)让 μ^+ 超线性减小，收敛速度也变成超线性。

这个估计假设单位步可以走，定理本身没有保证这一点，还要证明 $\alpha = 1$ 满足比例规则：活动约束的 s_i 和不活动约束的 λ_i 都是 $O(\mu)$ 量级的小量，方向也必须是相应量级，这需要参数更新不能太快，也需要 $\eta \to 1$。完整的论证较长，读者可查阅专著[4]。

全局的情形　从任意点出发，非凸问题上能证明的是：在迭代点有界、矩阵经过惯性修正、约束正则等假设下，带过滤器或合成目标检验的算法的极限点要么满足 KKT 条件，要么是约束违反量的驻点。这里没有全局最优的保证，图 24.8已经说明，路径本身可能走向较差的局部解。表 24.4总结了两类问题上结论的区别。

问题	凸问题	一般非凸问题
路径	整条存在且唯一	只在 KKT 点附近
路径上的间隙	$f - f^\star \le m\mu$	无全局含义
迭代界	自协调时 $\sqrt{\vartheta}$ 型	无
停止的含义	近似全局解的证书	近似 KKT 点
不可行的判定	可给证书	只能报告局部驻点
局部速度	超线性	正则性下超线性

表 24.4　内点法在凸问题与非凸问题上的结论。

每一轮的代价　一轮的工作分三块：计算 f、$\boldsymbol{g}$、$\boldsymbol{h}$ 及其一二阶导数，分解线性系统，以及可能的回溯。回溯只重新计算函数值，比较便宜。决定性的是分解。

压缩矩阵 $\tilde{\boldsymbol{H}} = \boldsymbol{W} + \boldsymbol{J}^{\top}\boldsymbol{D}\boldsymbol{J}$ 是 $n \times n$ 的。若有一条约束涉及很多变量，$\boldsymbol{J}$ 有一个稠密的行，$\boldsymbol{J}^{\top}\boldsymbol{D}\boldsymbol{J}$ 就是稠密的。鞍点形式 (24.24)维数大，却保留了稀疏性。

图 24.24是一个 $n = m = 20$ 的算例，$\boldsymbol{J}$ 是双对角的，最后一行稠密，共 58 个非零元，取 $\boldsymbol{W} = \boldsymbol{I}$。压缩矩阵完全稠密，它的下三角因子有 210 个非零元。40×40 的鞍点矩阵把稠密行排在最后，下三角因子只有 117 个非零元。

这和第 4章的 $\boldsymbol{A}\boldsymbol{D}\boldsymbol{A}^{\top}$ 是同一个现象，只是这里还多了 $\boldsymbol{W}$。稠密情形下，$n \times n$ 的分解需要约 $n^3/3$ 次运算；鞍点矩阵不定，要用 $\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\top}$ 分解和主元

选择，主元顺序会随数值改变，符号分析不能像线性规划那样只做一次。每试一个 δ_w 就要重新分解一次。

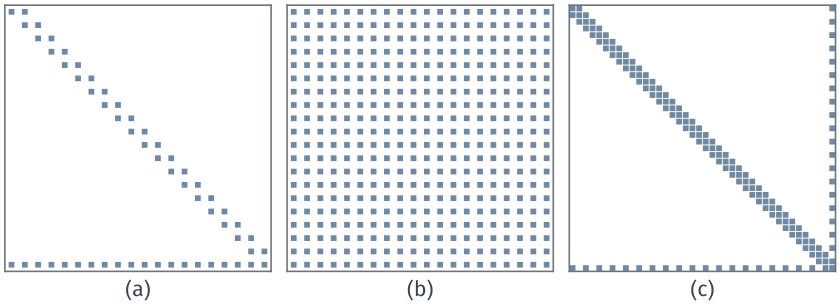


图 24.24 三个矩阵的非零模式，蓝点表示非零元。(a)20×20 的 Jacobian 矩阵，双对角加上一个稠密行。(b) 压缩矩阵 $\boldsymbol{W} + \boldsymbol{J}^{\mathsf{T}}\boldsymbol{D}\boldsymbol{J}$，完全稠密。(c) 鞍点矩阵 $[\boldsymbol{W}, \boldsymbol{J}^{\mathsf{T}}; \boldsymbol{J}, -\boldsymbol{D}^{-1}]$，变量与约束交错排列，稠密行排在最后。

条件数 $\boldsymbol{D}$ 的对角元是 λ_i/s_i。$\mu \to 0$ 时，活动约束上它约为 $(\lambda_i^\star)^2/\mu$，趋于无穷，不活动约束上它约为 $\mu/(s_i^\star)^2$，趋于零，矩阵的条件数按 $1/\mu$ 增长。

图 24.25显示，贯穿例的压缩矩阵和鞍点矩阵都是如此，保留鞍点结构并不能消除这种病态，它的好处在稀疏性。这种病态的结构很特殊，向后稳定的直接分解能够得到足够准确的方向；迭代法就没有这样幸运，共轭梯度类的方法在 μ 小时需要专门的预条件子。

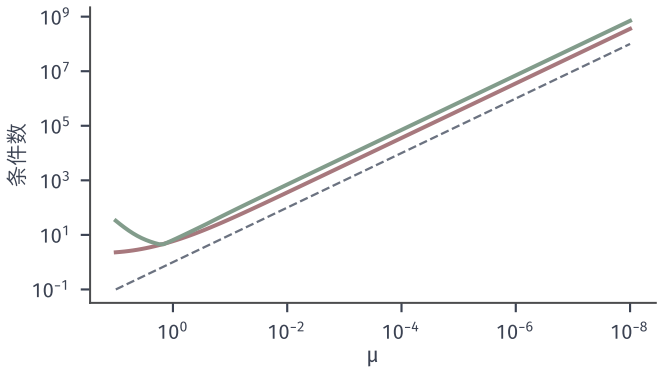


图 24.25 贯穿例沿中心路径的条件数，横轴是 μ，向右减小。红线是压缩矩阵 $\tilde{\boldsymbol{H}}$，绿线是鞍点矩阵，灰色虚线是参照线 $1/\mu$。两条曲线都按 $1/\mu$ 增长。

外层轮数 总代价等于外层轮数乘以每轮的分解代价。实际问题上，原始—对偶方法通常几十轮结束，这是经验而不是定理，它在式 (24.55)的界之下很多。

24.1 障碍问题
24.2 原始—对偶内点法
24.3 初始化与精度
24.4 锥规划中的障碍
24.5 保证与计算成本
24.6 本章小结

与第 21章的可行迭代和第 22章的乘子方法相比，内点法每轮的代价高，轮数少。能够精确分解时，内点法很有优势；分解太贵、只能得到低精度解就够时，一阶方法更合适。

24.6 本章小结

本章开头的问题是，约束变弯之后，线性规划的路径跟踪还剩下什么。骨架都留下了：在不等式上加对数障碍，驻定条件给出扰动互补 $s_i\lambda_i = \mu$，让 μ 减小到零。等式约束没有内部，仍要显式保留。

新增的内容来自曲率。障碍的 Hessian 多了 $\nabla^2 g_i/(-g_i)$ 一项，Newton 系统左上角多了 Lagrange Hessian，松弛方程的残差不再按 $1-\alpha$ 的比例下降。非凸时，矩阵可能在切空间上不正定，解方程得到的方向可能是上升方向，要靠惯性检查和矩阵正则化修正，再由残差检验或过滤器决定接受哪一步。

内部性、中心性和最优性是三种不同的检查对象。$\boldsymbol{s},\boldsymbol{\lambda} > \mathbf{0}$ 由到边界的比例规则维护，中心性由 σ 和邻域控制，最优性只能由驻定残差、约束残差和互补量共同判断。很小的 μ 或很小的 E_μ 都不是原问题的结论，最后要按未经修改的问题报告。

起点有两种。障碍路径需要严格可行点，可以用辅助问题求出；原始—对偶迭代只要求 $\boldsymbol{s},\boldsymbol{\lambda} > \mathbf{0}$，可以从非零残差出发。没有严格内点、约束重复或线性相关时，问题出在模型上，需要单独检查。

二阶锥和半正定锥有各自的障碍 $-\log(t^2 - \|\boldsymbol{u}\|_2^2)$ 和 $-\log\det \boldsymbol{X}$，路径和间隙的形式不变，n 换成障碍参数 ϑ。步长由二次方程或特征值给出。矩阵互补不能照搬标量操作，$\Delta\boldsymbol{X}$ 要经缩放保持对称，内积配对也要前后一致。

能给出什么结论，由模型的条件决定。凸问题上有整条路径、间隙 $m\mu$、近似点的误差界，自协调时还有 $\sqrt{\vartheta}$ 型的迭代界。一般非凸问题只有 KKT 点附近的局部路径和局部收敛，路径可以断开，也可能通向较差的解，线性规划的多项式结论不能外推。

计算上，每轮的主要代价是分解 Jacobian 和 Lagrange Hessian 组成的鞍点矩阵。压缩形式维数小但可能稠密，鞍点形式保留稀疏性，两者的条件数都按 $1/\mu$ 增长。

第 25 章

流形优化

求一个对称矩阵的最小特征向量，可以写成单位球面上的极小化。本章全程使用下面这个三维小例子：

$$\min_{\boldsymbol{x}\in\mathbb{R}^3} f(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x} \quad \text{s.t.} \quad \boldsymbol{x}^\top\boldsymbol{x} = 1, \qquad \boldsymbol{A} = \operatorname{diag}(1,2,4). \tag{25.1}$$

$\boldsymbol{A}$ 是对角矩阵，答案一眼可见：极小点是 $\pm\boldsymbol{e}_1$，最优值 $f^\star = \frac{1}{2}$。这样我们可以把注意力放在算法的每一步上，并随时核对结果。起点取

$$\boldsymbol{x}^{(0)} = \frac{1}{3}(2,2,1)^\top, \qquad f(\boldsymbol{x}^{(0)}) = \frac{8}{9}.$$

普通梯度步会马上碰到麻烦。图 25.1(a) 中，沿切线方向走一步，点就飘到球面之外；图 25.1(b) 中，矩阵的两列本来相互正交且长度为一，走一步后两列既不等长也不再正交。第 21章在圆周上用过局部消元再解方程恢复可行的办法，那里需要选基本变量，并在基矩阵病态时换基。

25.1 流形上的优化问题
25.2 最优性与导数计算
25.3 迭代的几何运算
25.4 一阶方法
25.5 二阶方法
25.6 拟 Newton 法
25.7 黎曼信赖域
25.8 表示与计算成本
25.9 本章小结

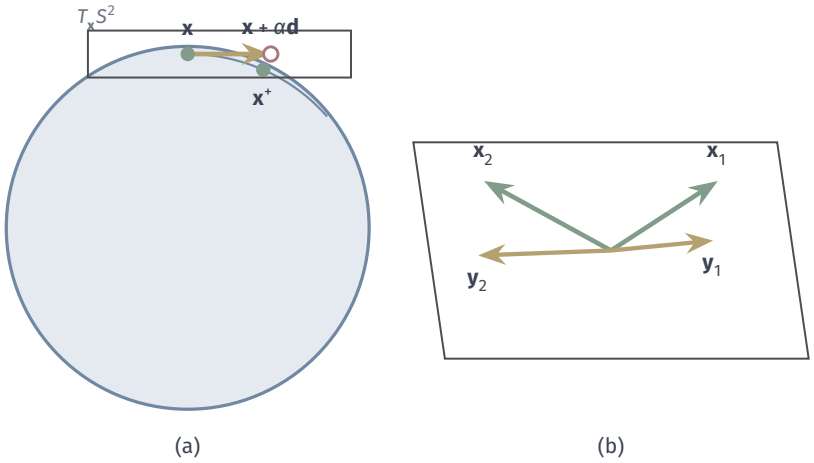


图 25.1 欧氏更新破坏光滑约束。(a) 浅蓝球面是可行集，方框是切平面的一块，黄箭头是切向的一步，红圈是落在球面外的点，虚线把它沿径向拉回到绿点。(b) 矩阵 $\boldsymbol{X}$ 的两列 $\boldsymbol{x}_1, \boldsymbol{x}_2$（绿）标准正交，方框是它们张成的平面；走一步后的两列 $\boldsymbol{y}_1, \boldsymbol{y}_2$（黄）长度约为 1.094 和 1.144，内积约为 0.247，都离开了约束。

球面和正交矩阵的集合比一般的弯曲约束多一项便利：它们是光滑流形，而且切空间和回到集合上的运算都有便宜的公式。这一章的问题是：能否把这个集合本身当作计算空间，让迭代从头到尾都在集合上走，同时保留梯度法、Newton 法、拟 Newton 法和信赖域的思路？

路线分三层。第 25.1节和第 25.2节确定问题的形式和最优性条件，并算出切向梯度与切向曲率。第 25.3节回答迭代缺少的三种运算：走完怎样回到集合上，怎样评价候选步，不同点处的向量怎样比较。

第 25.4节到第 25.7节依次把这些运算装进一阶方法、二阶方法、拟 Newton 法和信赖域，每种方法都在上面的小例子上手算几步。第 25.8节用子空间问题说明表示方式的影响，并在同一目标和同一精度下比较流形方法与一般约束方法。

25.1 流形上的优化问题

什么样的约束集合可以当作计算空间？本节先看两个具体约束，指出它们共有的结构，再说明这一结构在哪些集合上不存在。

两个具体约束 球面约束 $\boldsymbol{x}^{\top}\boldsymbol{x} = 1$ 只有一个方程。从点 $\boldsymbol{x}$ 出发沿曲线 $\boldsymbol{c}(t)$ 运动，并一直留在球面上，就要求 $\boldsymbol{c}(t)^{\top}\boldsymbol{c}(t) = 1$。对 t 求导并取 $t = 0$，得到速度 $\boldsymbol{v} = \boldsymbol{c}'(0)$ 必须满足

$$\boldsymbol{x}^{\top}\boldsymbol{v} = 0.$$

因此 $\boldsymbol{x}$ 处允许的运动方向是与 $\boldsymbol{x}$ 垂直的全体向量，构成一个 $n-1$ 维的线性子空间。

矩阵约束 $\boldsymbol{X}^{\top}\boldsymbol{X}=\boldsymbol{I}_k$ 的方程更多。这里 $\boldsymbol{X}\in\mathbb{R}^{n\times k}$，$k\le n$，它的列是一组标准正交向量。同样沿曲线 $\boldsymbol{C}(t)$ 求导，速度 $\boldsymbol{\Delta}=\boldsymbol{C}'(0)$ 必须满足

$$\boldsymbol{X}^{\top}\boldsymbol{\Delta}+\boldsymbol{\Delta}^{\top}\boldsymbol{X}=\boldsymbol{0}.$$

这个条件说的是 $\boldsymbol{X}^{\top}\boldsymbol{\Delta}$ 是反对称矩阵。例如 $n=3$，$k=2$ 时，矩阵有 6 个元素，约束有 3 个独立方程，所以允许的方向构成一个 3 维子空间。

两个例子的共同点是：约束对变量的允许变化作出限制，而这个限制在每一点都是一个线性子空间，维数处处相同。这正是后面所有方法的立足点，在每一点都有一张平坦的“工作台”，可以在上面做线性代数。

正则等式约束给出流形 把上面的观察写成一般形式。设 $h:\mathbb{R}^n\to\mathbb{R}^p$ 光滑，可行集是它的零点集：

$$M=\{\boldsymbol{x}\in\mathbb{R}^n:\ h(\boldsymbol{x})=\boldsymbol{0}\}. \tag{25.2}$$

记 $\boldsymbol{J}(\boldsymbol{x})$ 为 h 在 $\boldsymbol{x}$ 处的 Jacobian 矩阵，假定它在 M 的每一点都行满秩。这就是第 17章的线性无关约束规范，这里要求它在整个可行集上成立。

这个条件保证 M 是 $n-p$ 维的嵌入子流形，切空间就是 Jacobian 的零空间：

$$T_{\boldsymbol{x}}M=\ker\boldsymbol{J}(\boldsymbol{x}). \tag{25.3}$$

这里用到的是正则水平集定理及切空间的刻画，可参考卷四第 26 章“流形之间的关系”。球面取 $h(\boldsymbol{x})=\boldsymbol{x}^{\top}\boldsymbol{x}-1$，$\boldsymbol{J}(\boldsymbol{x})=2\boldsymbol{x}^{\top}$ 在球面上不为零；矩阵约束取值于对称矩阵，同样满足这个条件。

流形上的优化问题写作

$$\min_{\boldsymbol{x}\in M}\ f(\boldsymbol{x}), \tag{25.4}$$

其中 f 定义在包含 M 的开集上并且光滑。本章把 M 就当作前面各章的可行集 $\boldsymbol{C}$，并沿用卷四的写法把流形记成 M，把球面记成 S^{n-1}，把正交列矩阵的集合记成 Stiefel 流形 $\mathrm{St}(k,n)$。问题本身仍是约束极值，改变的只是求解时使用的计算空间。

集合、度量与表示 “在流形上计算”牵涉三个不同的选择，混淆它们会带来错误的结论。集合 M 由问题决定，它规定了哪些点可行，哪些点是极小点。

黎曼度量(Riemannian metric)是在每个切空间放一个内积,记为 $\langle\boldsymbol{u},\boldsymbol{v}\rangle_{\boldsymbol{x}}$。同一个集合可以配不同的度量。度量决定长度和角度，因而决定“最陡”

的方向，但不改变极小点的位置。本章除特别说明外，都取欧氏内积限制到切空间上的诱导度量。

表示方式是在计算机里怎样存一个点。球面上的点可以存成三个坐标，也可以存成两个角度；一个子空间可以存成任意一组基，这时同一个对象有许多矩阵记录。表示决定存储和运算的代价，第 25.8节专门讨论。表 25.1把三者并列。

表 25.1 流形优化中三种不同的选择。

选择	决定什么	不决定什么
集合 M	可行点、极小点	梯度的数值
度量 $\langle \cdot,\cdot \rangle_x$	梯度、Hessian、步长的尺度	极小点的位置
表示	存储和运算成本	所求的几何对象

带奇点或棱角的集合 前面的立足点并非总存在。图 25.2对比了三种集合。圆周上每点都有一条切线，法向量 ∇h 不为零，这是正则的情形。

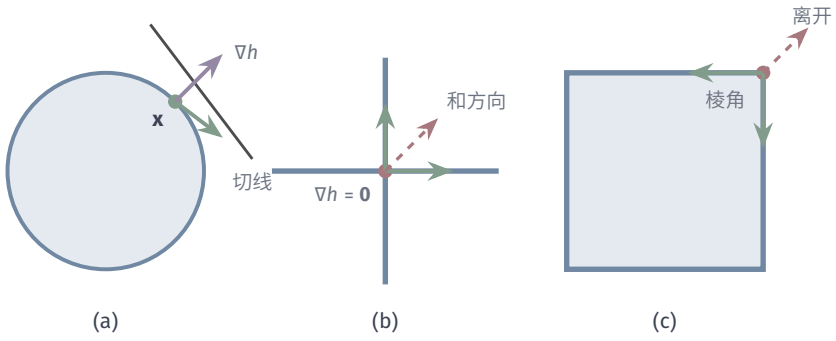


图 25.2 三种约束集合。(a) 圆周处处正则，切方向（绿）构成一条直线，紫箭头是约束的梯度。(b) 十字形 $x_1x_2 = 0$ 在原点处约束梯度为零，两个绿色可行方向之和（红虚线）不可行，可行方向不构成线性子空间。(c) 正方形的角点处，可行方向只有一个锥，朝外的方向（红虚线）不可行。

十字形 $\{x_1x_2 = 0\}$ 在原点处有两条可行的直线，把两个可行方向相加却得到不可行的方向，所以那里没有一个线性的切空间。这里 $\nabla(x_1x_2)$ 在原点为零，正则条件不成立。

棱角的情形类似。方形可行域的角点处，允许的方向只构成一个锥，负向不再允许。这类可行集要用第 21章的投影或第 22章的乘子方法，本章的迭代不能直接套用，因为后面每一步都假定当前点处有一个完整的线性切空间。

25.2 最优性与导数计算

25.1 流形上的优化问题
25.2 最优性与导数计算
25.3 迭代的几何运算
25.4 一阶方法
25.5 二阶方法
25.6 拟 Newton 法
25.7 黎曼信赖域
25.8 表示与计算成本
25.9 本章小结

普通的判据 $\nabla f = \mathbf{0}$ 在球面上失效：在极小点 $\boldsymbol{e}_1$ 处，∇f 等于 $\boldsymbol{e}_1$，并不为零。约束下应该把哪个量算成零，怎样判别二阶情形，这些量在具体约束上怎样计算？

切向梯度 黎曼度量的作用之一是把微分变成向量：$\operatorname{grad} f(\boldsymbol{x})$ 是 $T_{\boldsymbol{x}}M$ 中满足下式的唯一向量，$\mathrm{d}f_{\boldsymbol{x}}$ 是 f 在 $\boldsymbol{x}$ 处的微分。

$$\langle \operatorname{grad} f(\boldsymbol{x}), \boldsymbol{v} \rangle_{\boldsymbol{x}} = \mathrm{d}f_{\boldsymbol{x}}[\boldsymbol{v}], \qquad \forall\, \boldsymbol{v} \in T_{\boldsymbol{x}}M. \tag{25.5}$$

这个向量称为**黎曼梯度**（Riemannian gradient）。微分和度量的具体定义见卷四第 28 章“流形上的微积分”，这里只用它的计算结果。

度量如何影响梯度？设切空间上的内积由对称正定矩阵 $\boldsymbol{G}$ 给出，微分的系数向量记为 $\boldsymbol{c}$。式 (25.5)化成

$$\boldsymbol{v}^{\mathsf{T}} \boldsymbol{G} \operatorname{grad} f = \boldsymbol{v}^{\mathsf{T}} \boldsymbol{c}, \qquad \forall\, \boldsymbol{v},$$

于是

$$\operatorname{grad} f = \boldsymbol{G}^{-1} \boldsymbol{c}.$$

取 $\boldsymbol{c} = (1,1)^{\mathsf{T}}$ 做比较。$\boldsymbol{G} = \boldsymbol{I}$ 时梯度是 $(1,1)^{\mathsf{T}}$；$\boldsymbol{G} = \operatorname{diag}(4,1)$ 时梯度是 $(\frac{1}{4},1)^{\mathsf{T}}$。

图 25.3解释这个差别。绿色区域是该度量下的单位球，梯度方向指向单位球上使线性函数最大的那一点。度量把单位球压扁，切点就移动了。两种度量下，梯度为零的条件都是 $\boldsymbol{c} = \mathbf{0}$，所以驻点不受影响。

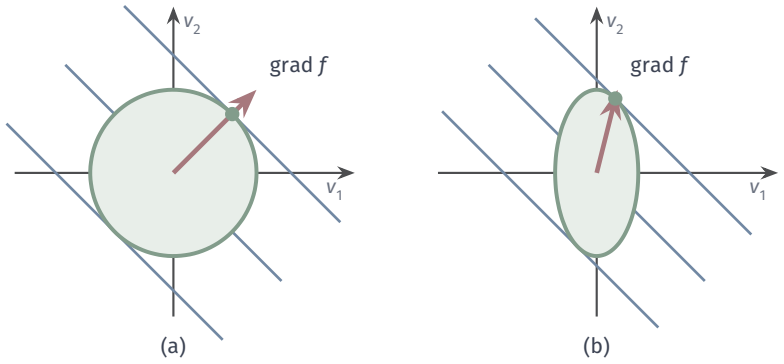


图 25.3 同一微分在两种度量下的梯度。蓝线是线性函数 $\mathrm{d}f[\boldsymbol{v}] = v_1 + v_2$ 的等值线，绿色区域是度量的单位球，绿点是单位球上函数值最大的点，红箭头是梯度。(a) $\boldsymbol{G} = \boldsymbol{I}$。(b) $\boldsymbol{G} = \operatorname{diag}(4,1)$，单位球沿 v_1 被压缩，梯度偏向 v_2。

诱导度量下用投影计算　取诱导度量时，黎曼梯度有一个直接的算法。设 $\bar f$ 是 f 在环境空间中的光滑延拓，$\boldsymbol{P}_{\boldsymbol{x}}$ 是到 $T_{\boldsymbol{x}}M$ 的正交投影。下面的引理说明，只要把欧氏梯度投影一下。

引理 25.1　投影公式　设 $M \subseteq \mathbb{R}^n$ 是嵌入子流形，取诱导度量，$\bar f$ 在 M 的邻域内光滑且在 M 上等于 f。则

$$\operatorname{grad} f(\boldsymbol{x}) = \boldsymbol{P}_{\boldsymbol{x}} \nabla \bar f(\boldsymbol{x}). \tag{25.6}$$

证明　对 $\boldsymbol{v} \in T_{\boldsymbol{x}}M$，取 M 上的曲线 $\boldsymbol{c}$，满足 $\boldsymbol{c}(0) = \boldsymbol{x}$，$\boldsymbol{c}'(0) = \boldsymbol{v}$。因为 f 与 $\bar f$ 在 M 上相等，

$$\mathrm{d}f_{\boldsymbol{x}}[\boldsymbol{v}] = \frac{\mathrm{d}}{\mathrm{d}t} \bar f(\boldsymbol{c}(t))\Big|_{t=0} = \langle \nabla \bar f(\boldsymbol{x}), \boldsymbol{v} \rangle.$$

$\boldsymbol{P}_{\boldsymbol{x}}$ 是正交投影，$\boldsymbol{v}$ 在切空间中，所以 $\boldsymbol{P}_{\boldsymbol{x}}\boldsymbol{v} = \boldsymbol{v}$，并且投影对称，于是

$$\langle \nabla \bar f(\boldsymbol{x}), \boldsymbol{v} \rangle = \langle \nabla \bar f(\boldsymbol{x}), \boldsymbol{P}_{\boldsymbol{x}}\boldsymbol{v} \rangle = \langle \boldsymbol{P}_{\boldsymbol{x}} \nabla \bar f(\boldsymbol{x}), \boldsymbol{v} \rangle.$$

$\boldsymbol{P}_{\boldsymbol{x}} \nabla \bar f(\boldsymbol{x})$ 在切空间中，又满足定义式 (25.5)，由唯一性得结论。 ■

投影公式的适用条件是诱导度量，这一点不能省略。换了别的度量，还须按上一段的公式乘以度量的逆。

球面 Rayleigh 商　把公式用到贯穿例。球面上的投影去掉沿 $\boldsymbol{x}$ 的分量：

$$\boldsymbol{P}_{\boldsymbol{x}}\boldsymbol{z} = \boldsymbol{z} - (\boldsymbol{x}^{\mathsf{T}}\boldsymbol{z})\boldsymbol{x}.$$

记Rayleigh 商（Rayleigh quotient）的取值为 $q(\boldsymbol{x}) = \boldsymbol{x}^{\mathsf{T}}\boldsymbol{A}\boldsymbol{x}$，这里 $\|\boldsymbol{x}\|_2 = 1$。欧氏梯度是 $\boldsymbol{A}\boldsymbol{x}$，$\boldsymbol{x}^{\mathsf{T}}\boldsymbol{A}\boldsymbol{x} = q$，所以

$$\operatorname{grad} f(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} - q(\boldsymbol{x})\boldsymbol{x}. \tag{25.7}$$

在起点 $\boldsymbol{x}^{(0)}$ 上算一遍。先算下面三个量：

$$\boldsymbol{A}\boldsymbol{x}^{(0)} = \frac{1}{3}(2,4,4)^{\mathsf{T}}, \qquad q(\boldsymbol{x}^{(0)}) = \frac{4+8+4}{9} = \frac{16}{9}.$$

代入式 (25.7)，得到

$$\boldsymbol{g}^{(0)} = \frac{1}{3}(2,4,4)^{\mathsf{T}} - \frac{16}{27}(2,2,1)^{\mathsf{T}} = \frac{1}{27}(-14,4,20)^{\mathsf{T}}.$$

可以检查它在切空间中：$\boldsymbol{x}^{(0)\top}\boldsymbol{g}^{(0)} = (-28 + 8 + 20)/81 = 0$。范数的平方是

$$\|\boldsymbol{g}^{(0)}\|_2^2 = \frac{196 + 16 + 400}{729} = \frac{68}{81}.$$

图 25.4画出这次分解。蓝色的欧氏梯度分成两段，紫色部分沿法向，只会改变到球面的距离，绿色部分才对球面上的运动起作用。

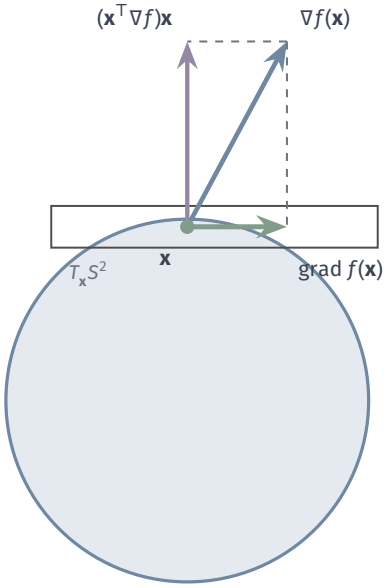


图 25.4　起点 $\boldsymbol{x}^{(0)}$ 处欧氏梯度的分解。蓝箭头是 ∇f，紫箭头是法向分量，绿箭头是切向分量即黎曼梯度，方框是切平面的一块。三个箭头按同一比例缩短到原长的 0.6 倍。

一阶条件与 Lagrange 乘子　现在把切向梯度与第 17章的乘子联系起来。由式 (25.3)，$T_{\boldsymbol{x}}M$ 的正交投影可以写成

$$\boldsymbol{P}_{\boldsymbol{x}} = \boldsymbol{I} - \boldsymbol{J}^\top(\boldsymbol{J}\boldsymbol{J}^\top)^{-1}\boldsymbol{J},$$

这里行满秩保证 $\boldsymbol{J}\boldsymbol{J}^\top$ 可逆。

把投影代入式 (25.6)，并定义乘子

$$\boldsymbol{\nu}(\boldsymbol{x}) = -(\boldsymbol{J}\boldsymbol{J}^\top)^{-1}\boldsymbol{J}\nabla\bar{f}(\boldsymbol{x}), \tag{25.8}$$

就得到

$$\operatorname{grad} f(\boldsymbol{x}) = \nabla\bar{f}(\boldsymbol{x}) + \boldsymbol{J}(\boldsymbol{x})^\top\boldsymbol{\nu}(\boldsymbol{x}) = \nabla_{\boldsymbol{x}}\mathcal{L}(\boldsymbol{x}, \boldsymbol{\nu}(\boldsymbol{x})). \tag{25.9}$$

所以黎曼梯度正是 Lagrange 函数对 $\boldsymbol{x}$ 的梯度，乘子取使 $\|\nabla\bar{f} + \boldsymbol{J}^\top\boldsymbol{\nu}\|_2$ 最小的最小二乘乘子。黎曼梯度为零，就是 Lagrange 乘子驻定条件。

球面上 $h(\boldsymbol{x}) = \boldsymbol{x}^{\top}\boldsymbol{x} - 1$，$\boldsymbol{J} = 2\boldsymbol{x}^{\top}$，$\boldsymbol{J}\boldsymbol{J}^{\top} = 4$，代入式 (25.8)得到

$$\nu(\boldsymbol{x}) = -\frac{1}{4}\cdot 2\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x} = -\frac{1}{2}q(\boldsymbol{x}).$$

梯度为零的条件 $\boldsymbol{A}\boldsymbol{x} = q\boldsymbol{x}$ 说明，驻点恰好是 $\boldsymbol{A}$ 的单位特征向量，并且 q 就是特征值。贯穿例有六个驻点 $\pm\boldsymbol{e}_1, \pm\boldsymbol{e}_2, \pm\boldsymbol{e}_3$。

图 25.5是目标在球面上的等高线。红点 $\boldsymbol{e}_1$ 周围的闭合曲线表明这里是极小点，$\boldsymbol{e}_3$ 是极大点，$\boldsymbol{e}_2$ 处等高线呈交叉状，它是鞍点。

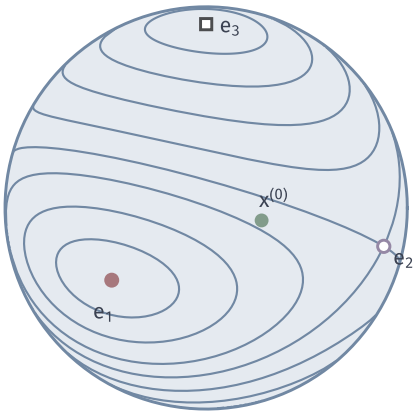


图 25.5　贯穿例的目标在单位球面上的等高线（蓝），只画朝向读者的半球。红点是极小点 $\boldsymbol{e}_1$，紫圈是鞍点 $\boldsymbol{e}_2$，方块是极大点 $\boldsymbol{e}_3$，绿点是起点。背面半球的 $-\boldsymbol{e}_1, -\boldsymbol{e}_2, -\boldsymbol{e}_3$ 有相同的情形。

切向曲率　一阶条件分不开 $\boldsymbol{e}_1, \boldsymbol{e}_2, \boldsymbol{e}_3$，需要二阶信息。**黎曼** Hessian（Riemannian Hessian）是切空间 $T_{\boldsymbol{x}}M$ 到自身的对称线性算子，记为 $\operatorname{Hess} f(\boldsymbol{x})$，定义为黎曼梯度沿切向量的协变导数，其几何来历可参考卷四第 27 章“黎曼几何”。

诱导度量下的协变导数是先做普通方向导数再投影，所以只要把黎曼梯度光滑延拓成环境空间中的向量场 $\boldsymbol{G}$，就有

$$\operatorname{Hess} f(\boldsymbol{x})[\boldsymbol{v}] = \boldsymbol{P}_{\boldsymbol{x}}\,\mathrm{D}\boldsymbol{G}(\boldsymbol{x})[\boldsymbol{v}]. \tag{25.10}$$

球面上把式 (25.7)的右端在整个空间中当作 $\boldsymbol{G}(\boldsymbol{x})$，方向导数是

$$\mathrm{D}\boldsymbol{G}(\boldsymbol{x})[\boldsymbol{v}] = \boldsymbol{A}\boldsymbol{v} - 2(\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{v})\boldsymbol{x} - q(\boldsymbol{x})\boldsymbol{v}.$$

第二项沿法向，投影后消失；第三项本身是切向的。于是

$$\operatorname{Hess} f(\boldsymbol{x})[\boldsymbol{v}] = \boldsymbol{P}_{\boldsymbol{x}}\big(\boldsymbol{A}\boldsymbol{v}\big) - q(\boldsymbol{x})\boldsymbol{v}, \qquad \boldsymbol{v} \perp \boldsymbol{x}. \tag{25.11}$$

这个式子里的 $-q\boldsymbol{v}$ 值得留意。欧氏 Hessian 是 $\boldsymbol{A}$，而切向曲率还要减去 q，这一项来自约束本身的弯曲，由乘子项承担，下面马上看到。

在驻点上用这个公式。取 $\boldsymbol{x}=\boldsymbol{e}_i$，$q=\lambda_i$，切空间由其余两个坐标向量张成，算子是对角的。三个驻点的切向曲率如表 25.2所示。

表 25.2　贯穿例的驻点，切向曲率由式 (25.11)算出。

驻点	q	切向曲率	类型
$\pm\boldsymbol{e}_1$	1	$2-1=1,\ 4-1=3$	严格局部极小，全局极小
$\pm\boldsymbol{e}_2$	2	$1-2=-1,\ 4-2=2$	鞍点
$\pm\boldsymbol{e}_3$	4	$1-4=-3,\ 2-4=-2$	严格局部极大

图 25.6把三类驻点放到各自的切平面坐标里看。图中的函数值是把切向量先归一化回球面后计算的，局部形状与表中的符号一致。

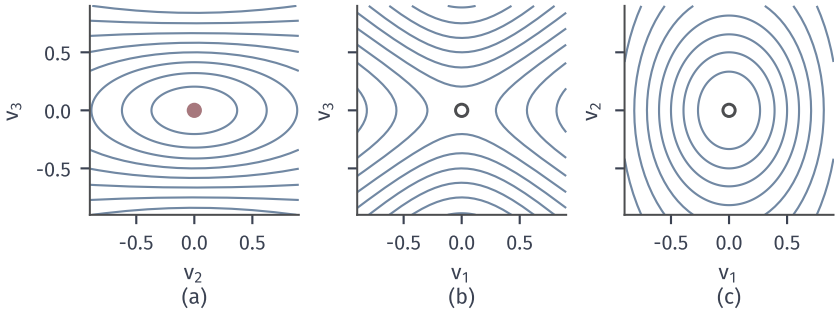


图 25.6　三类驻点附近的局部形状。蓝线是 $f(\boldsymbol{x}+\boldsymbol{v})/\|\boldsymbol{x}+\boldsymbol{v}\|_2^2$ 的等值线，这里的 f 在贯穿例中是二次齐次的，该式等于把 $\boldsymbol{x}+\boldsymbol{v}$ 归一化后的目标值。(v_i,v_j) 是切平面坐标。(a) $\boldsymbol{e}_1$，碗形。(b) $\boldsymbol{e}_2$，马鞍形。(c) $\boldsymbol{e}_3$，倒扣的碗。

曲率与 Lagrange 函数的 Hessian　为什么约束的弯曲会以乘子的形式进入？设 $\boldsymbol{c}(t)$ 是 M 上的曲线，$\boldsymbol{c}(0)=\boldsymbol{x}$，$\boldsymbol{c}'(0)=\boldsymbol{v}$。由 $h_j(\boldsymbol{c}(t))=0$ 求两次导，得到

$$\nabla h_j(\boldsymbol{x})^{\top}\boldsymbol{c}''(0)+\boldsymbol{v}^{\top}\nabla^2 h_j(\boldsymbol{x})\boldsymbol{v}=0.$$

现在求目标沿曲线的二阶导数，它是

$$(\bar f\circ\boldsymbol{c})''(0)=\boldsymbol{v}^{\top}\nabla^2\bar f\,\boldsymbol{v}+\nabla\bar f^{\top}\boldsymbol{c}''(0).$$

由式 (25.9)把 $\nabla\bar f$ 换成黎曼梯度减去 $\boldsymbol{J}^{\top}\boldsymbol{\nu}$，再利用上一式把 $\nabla h_j^{\top}\boldsymbol{c}''(0)$ 换掉，就得到

$$(\bar f\circ\boldsymbol{c})''(0)=\boldsymbol{v}^{\top}\nabla^2_{\boldsymbol{xx}}\mathcal{L}(\boldsymbol{x},\boldsymbol{\nu}(\boldsymbol{x}))\boldsymbol{v}+\big\langle\operatorname{grad} f(\boldsymbol{x}),\boldsymbol{c}''(0)\big\rangle. \tag{25.12}$$

测地线的加速度是纯法向的，所以取 $\boldsymbol{c}$ 为测地线时最后一项为零，左端就是 $\langle \boldsymbol{v}, \operatorname{Hess} f(\boldsymbol{x})[\boldsymbol{v}]\rangle$。这样切向曲率等于 Lagrange 函数的 Hessian 在切空间上的二次型：

$$\langle \boldsymbol{v}, \operatorname{Hess} f(\boldsymbol{x})[\boldsymbol{v}]\rangle = \boldsymbol{v}^{\top} \nabla^2_{\boldsymbol{x}\boldsymbol{x}} \mathcal{L}(\boldsymbol{x}, \boldsymbol{\nu}(\boldsymbol{x}))\boldsymbol{v}, \qquad \boldsymbol{v} \in T_{\boldsymbol{x}} M. \tag{25.13}$$

球面上核对一下。Lagrange 函数的 Hessian 是

$$\nabla^2_{\boldsymbol{x}\boldsymbol{x}} \mathcal{L} = \boldsymbol{A} + 2\nu \boldsymbol{I} = \boldsymbol{A} - q\boldsymbol{I},$$

所以二次型是 $\boldsymbol{v}^{\top}\boldsymbol{A}\boldsymbol{v} - q\|\boldsymbol{v}\|_2^2$，与式 (25.11)相同。式 (25.12)最后那一项在第 25.3.2节还会用到。

二阶判别 下面的定理把上述量组织成判别条件，要分清必要与充分。

定理 25.2 流形上的最优性条件 设 f 在黎曼流形 M 上二阶连续可微，$\boldsymbol{x}^\star \in M$。

1. 若 $\boldsymbol{x}^\star$ 是局部极小点，则 $\operatorname{grad} f(\boldsymbol{x}^\star) = \boldsymbol{0}$，且 $\operatorname{Hess} f(\boldsymbol{x}^\star)$ 半正定。
2. 若 $\operatorname{grad} f(\boldsymbol{x}^\star) = \boldsymbol{0}$，且 $\operatorname{Hess} f(\boldsymbol{x}^\star)$ 在 $T_{\boldsymbol{x}^\star} M$ 上正定，则 $\boldsymbol{x}^\star$ 是严格局部极小点。

证明 记指数映射为 $\exp_{\boldsymbol{x}^\star}$，定义切空间上的函数

$$\phi(\boldsymbol{v}) = f(\exp_{\boldsymbol{x}^\star}(\boldsymbol{v})).$$

指数映射在零点的微分是恒等映射，由反函数定理，它把零点的一个邻域微分同胚地映到 $\boldsymbol{x}^\star$ 的一个邻域。

因此 $\boldsymbol{x}^\star$ 是 f 的（严格）局部极小点，当且仅当 $\boldsymbol{0}$ 是 ϕ 的（严格）局部极小点。对单位切向量 $\boldsymbol{v}$，曲线 $\gamma(t) = \exp_{\boldsymbol{x}^\star}(t\boldsymbol{v})$ 是测地线，于是

$$\frac{\mathrm{d}}{\mathrm{d}t}\phi(t\boldsymbol{v})\Big|_{t=0} = \langle \operatorname{grad} f(\boldsymbol{x}^\star), \boldsymbol{v}\rangle, \qquad \frac{\mathrm{d}^2}{\mathrm{d}t^2}\phi(t\boldsymbol{v})\Big|_{t=0} = \langle \boldsymbol{v}, \operatorname{Hess} f(\boldsymbol{x}^\star)[\boldsymbol{v}]\rangle.$$

这说明 ϕ 在零点的欧氏梯度和 Hessian 正是黎曼梯度和黎曼 Hessian。把线性空间上无约束问题的一阶、二阶必要条件和二阶充分条件用到 ϕ 上，就得到两个结论。 ■

两个条件之间有间隙，$\operatorname{Hess} f$ 半正定但不正定时，定理不作结论。取圆周上的 $f(\boldsymbol{x}) = x_2^3$，在点 $(1,0)$ 处切向坐标为 θ，$f = \sin^3\theta$ 的一阶、二阶导

25.1 流形上的优化问题
25.2 最优性与导数计算
25.3 迭代的几何运算
25.3.1 回缩
25.3.2 目标拉回
25.3.3 向量搬运
25.4 一阶方法
25.5 二阶方法
25.6 拟 Newton 法
25.7 黎曼信赖域
25.8 表示与计算成本
25.9 本章小结

数都为零，二阶必要条件成立，但 $\theta < 0$ 时函数值更小，这一点不是局部极小。

半正定也可能来自一整段极小点。取 $\boldsymbol{A} = \operatorname{diag}(1,1,4)$，圆周 $x_3 = 0$ 上每一点都是全局极小点，切向曲率有一个零方向，定理第二条不适用，这些点并不是孤立的。

定理也只是局部结论。圆周上的 $\cos 3\theta + 0.3\cos\theta$ 在 $\theta = \pi$ 附近和 $\theta = \pm\pi/3$ 附近都有严格局部极小，函数值分别约为 -1.30 和 -0.85，后者满足二阶充分条件却不是全局极小。

Rayleigh 商是一个少见的例外，局部极小都是全局极小。设 $\boldsymbol{x}$ 是特征向量，特征值 $\lambda > \lambda_1$，取 λ_1 的单位特征向量 $\boldsymbol{v}$，它与 $\boldsymbol{x}$ 正交，由式 (25.11)得到

$$\langle \boldsymbol{v}, \operatorname{Hess} f(\boldsymbol{x})[\boldsymbol{v}] \rangle = \lambda_1 - \lambda < 0.$$

所以满足二阶必要条件的驻点只能属于最小特征值。这个结论来自目标的特殊结构，不能推广到一般流形问题。

25.3 迭代的几何运算

现在假定当前点 $\boldsymbol{x}$ 处已经算出一个切向候选步 $\boldsymbol{v} \in T_{\boldsymbol{x}}M$。欧氏空间里接下来的事情都是加减法，到了流形上有三件事要重新回答：走完之后怎样回到集合上，怎样评价这一步好不好，历史上的向量在新点怎样使用。

图 25.7是后面所有算法共用的循环。切向候选步由各节的方法给出，其余三个方框分别由下面三小节回答。这里只讨论能在计算机上执行的运算，切空间、联络和指数映射的定义仍以卷四为准。

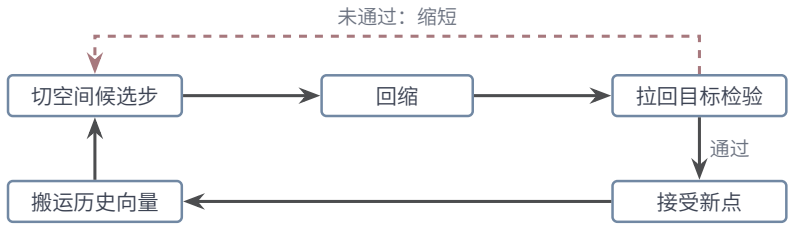


图 25.7 流形优化的一轮迭代。切空间里产生候选步，回缩把它变成流形上的候选点，再用拉回后的目标判断是否接受；接受后把需要保留的历史向量搬到新点的切空间。红色虚线表示判断未通过时缩短步长或半径。

25.1 流形上的优化问题
25.2 最优性与导数计算
25.3 迭代的几何运算
25.3.1 回缩
25.3.2 目标拉回
25.3.3 向量搬运
25.4 一阶方法
25.5 二阶方法
25.6 拟 Newton 法
25.7 黎曼信赖域
25.8 表示与计算成本
25.9 本章小结

25.3.1 回缩

用球面看需要什么 从 $\boldsymbol{x}$ 走到 $\boldsymbol{x}+\boldsymbol{v}$ 后，最自然的修正是除以长度，把点拉回球面：

$$R_{\boldsymbol{x}}(\boldsymbol{v}) = \frac{\boldsymbol{x}+\boldsymbol{v}}{\|\boldsymbol{x}+\boldsymbol{v}\|_2} = \frac{\boldsymbol{x}+\boldsymbol{v}}{\sqrt{1+\|\boldsymbol{v}\|_2^2}}. \tag{25.14}$$

第二个等号用到 $\boldsymbol{x}\perp\boldsymbol{v}$ 和勾股定理。这个映射有两条关键性质：零步不动，并且走很小的一步时，它和切向量给出的方向一致。

把第二条写成曲线的语言。令 $\boldsymbol{c}(t)=R_{\boldsymbol{x}}(t\boldsymbol{v})$，把分母按 t 展开，得到

$$\boldsymbol{c}(t) = (\boldsymbol{x}+t\boldsymbol{v})\Big(1-\frac{1}{2}t^2\|\boldsymbol{v}\|_2^2 + O(t^4)\Big).$$

由此读出 $\boldsymbol{c}(0)=\boldsymbol{x}$，$\boldsymbol{c}'(0)=\boldsymbol{v}$，加速度 $\boldsymbol{c}''(0)=-\|\boldsymbol{v}\|_2^2\boldsymbol{x}$ 沿法向。

这两条性质正是我们真正需要的，再多的要求（例如走出的曲线恰好是测地线）对一阶信息没有帮助。于是有下面的定义。

定义 25.3 回缩 流形 M 上的**回缩**（retraction）是一族光滑映射 $R_{\boldsymbol{x}}:U_{\boldsymbol{x}}\to M$，其中 $U_{\boldsymbol{x}}$ 是 $T_{\boldsymbol{x}}M$ 中包含零的开集，并且对所有 $\boldsymbol{x}\in M$，$\boldsymbol{v}\in T_{\boldsymbol{x}}M$ 有

$$R_{\boldsymbol{x}}(\boldsymbol{0})=\boldsymbol{x},\qquad \frac{\mathrm{d}}{\mathrm{d}t}R_{\boldsymbol{x}}(t\boldsymbol{v})\Big|_{t=0}=\boldsymbol{v}. \tag{25.15}$$

若进一步对所有 $\boldsymbol{v}$，曲线 $\boldsymbol{c}(t)=R_{\boldsymbol{x}}(t\boldsymbol{v})$ 的加速度满足 $\boldsymbol{P}_{\boldsymbol{x}}\boldsymbol{c}''(0)=\boldsymbol{0}$，则称它为**二阶回缩**（second-order retraction）。

二阶条件的提法依赖诱导度量：对嵌入子流形，它说的是加速度的切向分量为零。指数映射是最典型的二阶回缩，因为测地线加速度的切向分量恒为零。式 (25.14)由上面的展开也是二阶回缩。

回缩不等于指数映射 图 25.8(a) 在穿过球心的截面上比较两种走法。切向量长度为 s 时，指数映射沿大圆走过角度 s，归一化走过角度 $\arctan s$。

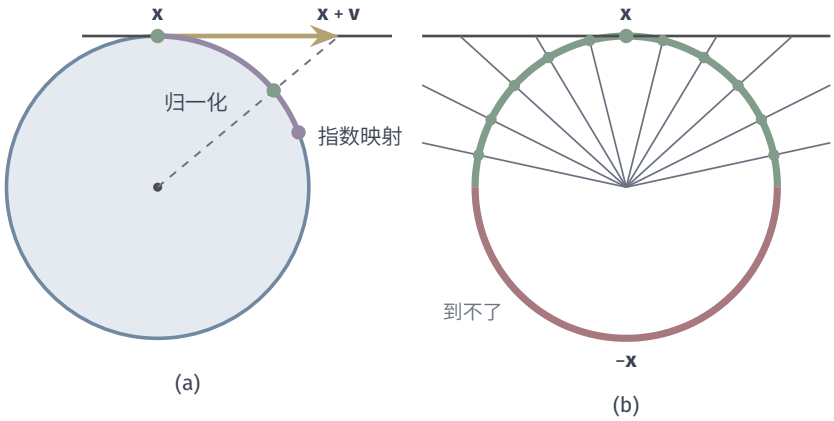


图 25.8 球面的截面。(a) 黄箭头是长度 1.2 的切向量，归一化把它的端点沿虚线径向拉回到绿点，紫弧是指数映射走过的路，端点在紫点。(b) 切线上的点全都被归一化映到上半圆（绿）。下半圆（红）到不了，对跖点 $-\boldsymbol{x}$ 也到不了。

两者的差在小步时很小。由 $\arctan s = s - s^3/3 + O(s^5)$，角度差是 $s^3/3$ 的量级，这是图 25.9(b) 的斜率 3。步子大了差距才明显：$s \to \infty$ 时归一化只能逼近 $\pi/2$，而指数映射走过的角度不断增长。

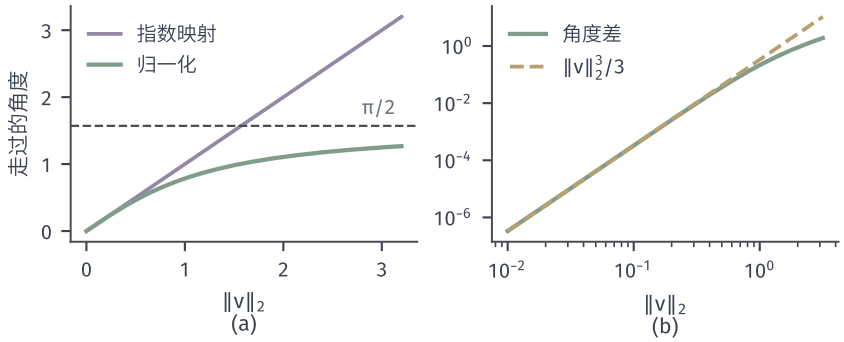


图 25.9 球面上切向量长度 $\|\boldsymbol{v}\|_2$ 与走过的角度。(a) 指数映射（紫）的角度等于长度，归一化（绿）的角度不超过 $\pi/2$。(b) 双对数坐标下两者的角度差（绿）与 $\|\boldsymbol{v}\|_2^3/3$（黄虚线）在小步时重合。

把切平面整张折到球面上，就看到回缩的全貌。图 25.10中，切平面上等间距的同心圆经过归一化后向边缘挤压，径向的射线变成大圆。这也提醒我们，回缩不是等距的，切空间里的长度只在原点附近才代表流形上走过的距离。

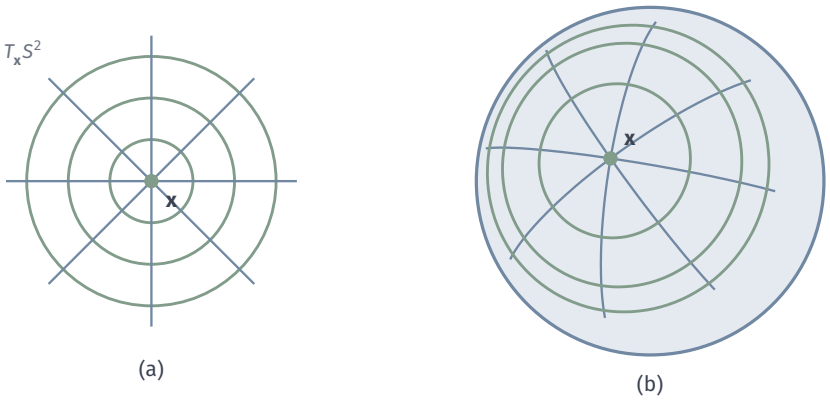


图 25.10 归一化回缩把切平面折到球面上。(a) 切平面上半径 0.5, 1, 1.5 的同心圆（绿）与八条射线（蓝）。(b) 它们在回缩下的像，同心圆的间距向外收紧，射线变成大圆的一段。

定义域 归一化公式对所有切向量都有定义，因为 $\boldsymbol{x} \perp \boldsymbol{v}$ 保证 $\boldsymbol{x} + \boldsymbol{v} \neq \boldsymbol{0}$，但它的像只覆盖开上半球，如图 25.8(b) 所示。定义 25.3只要求在零的邻域内有定义，这对迭代是足够的，因为每步只需要局部信息。

一般回缩可能只在局部有定义，分解还可能有多种选择。选择不固定就会使映射不光滑，下面的矩阵例子就有这个问题。

Stiefel 流形上的回缩 取 $\boldsymbol{X} \in \mathrm{St}(k, n)$，切向量 $\boldsymbol{\Delta}$ 满足 $\boldsymbol{X}^{\top}\boldsymbol{\Delta}$ 反对称。把 $\boldsymbol{X} + \boldsymbol{\Delta}$ 作 QR 分解 $\boldsymbol{X} + \boldsymbol{\Delta} = \boldsymbol{Q}\boldsymbol{R}$，其中 $\boldsymbol{R}$ 上三角且对角元为正，取 $\boldsymbol{Q}$ 作为新点：

$$R_{\boldsymbol{X}}^{\mathrm{QR}}(\boldsymbol{\Delta}) = \boldsymbol{Q}. \tag{25.16}$$

固定对角元为正这个选择是必要的，否则列的符号可以任意翻转，映射甚至不连续。分解一定存在且唯一，因为 $\boldsymbol{X}^{\top}\boldsymbol{\Delta}$ 反对称使两个交叉项抵消：

$$(\boldsymbol{X} + \boldsymbol{\Delta})^{\top}(\boldsymbol{X} + \boldsymbol{\Delta}) = \boldsymbol{I} + \boldsymbol{\Delta}^{\top}\boldsymbol{\Delta} \succ \boldsymbol{0},$$

所以 $\boldsymbol{X} + \boldsymbol{\Delta}$ 列满秩。

下面核对一阶一致性。令 $\boldsymbol{X} + t\boldsymbol{\Delta} = \boldsymbol{Q}(t)\boldsymbol{R}(t)$，$\boldsymbol{Q}(0) = \boldsymbol{X}$，$\boldsymbol{R}(0) = \boldsymbol{I}$。对 t 求导并在 $t = 0$ 左乘 $\boldsymbol{X}^{\top}$，得到

$$\boldsymbol{X}^{\top}\boldsymbol{\Delta} = \boldsymbol{X}^{\top}\boldsymbol{Q}'(0) + \boldsymbol{R}'(0).$$

左端反对称，右端第一项也反对称（对 $\boldsymbol{Q}(t)^{\top}\boldsymbol{Q}(t) = \boldsymbol{I}$ 求导得到），所以 $\boldsymbol{R}'(0)$ 既反对称又上三角，只能是零。代回求导式就得到 $\boldsymbol{Q}'(0) = \boldsymbol{\Delta}$。

第二种构造用极分解，把 $\boldsymbol{X}+\boldsymbol{\Delta}$ 的列正交化的同时尽量少动它：

$$R^{\mathrm{pol}}_{\boldsymbol{X}}(\boldsymbol{\Delta}) = (\boldsymbol{X}+\boldsymbol{\Delta})\big(\boldsymbol{I}+\boldsymbol{\Delta}^{\top}\boldsymbol{\Delta}\big)^{-1/2}. \tag{25.17}$$

结果确实在流形上：列满秩矩阵右乘 $(\boldsymbol{Y}^{\top}\boldsymbol{Y})^{-1/2}$ 后列标准正交。把逆平方根展开，得到

$$\boldsymbol{C}(t) = (\boldsymbol{X}+t\boldsymbol{\Delta})\Big(\boldsymbol{I} - \frac{1}{2}t^2\boldsymbol{\Delta}^{\top}\boldsymbol{\Delta} + O(t^4)\Big).$$

于是 $\boldsymbol{C}'(0)=\boldsymbol{\Delta}$，$\boldsymbol{C}''(0) = -\boldsymbol{X}\boldsymbol{\Delta}^{\top}\boldsymbol{\Delta}$。

后者形如 $\boldsymbol{X}\boldsymbol{B}$，其中 $\boldsymbol{B}$ 对称。为了判断它的切向分量，写出 $\mathrm{St}(k,n)$ 的切向投影

$$\boldsymbol{P}_{\boldsymbol{X}}(\boldsymbol{Z}) = \boldsymbol{Z} - \boldsymbol{X}\,\mathrm{sym}(\boldsymbol{X}^{\top}\boldsymbol{Z}), \qquad \mathrm{sym}(\boldsymbol{B}) = \frac{1}{2}(\boldsymbol{B}+\boldsymbol{B}^{\top}). \tag{25.18}$$

把 $\boldsymbol{Z}=\boldsymbol{X}\boldsymbol{B}$ 代入，得到 $\boldsymbol{X}\boldsymbol{B}-\boldsymbol{X}\boldsymbol{B}=\boldsymbol{0}$，所以极分解回缩是二阶回缩。QR 回缩一般只是一阶的，下面的例子中它的加速度有非零的切向分量。

用具体数字比较两种构造。在 $\mathrm{St}(2,3)$ 上取

$$\boldsymbol{X} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}, \qquad \boldsymbol{\Delta} = \begin{bmatrix} 0 & 0 \\ 0 & 0 \\ 1 & 1 \end{bmatrix}, \qquad \boldsymbol{Y} = \boldsymbol{X}+\boldsymbol{\Delta} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}.$$

这里 $\boldsymbol{X}^{\top}\boldsymbol{\Delta}=\boldsymbol{0}$，是切向量。

QR 分解按列正交化。第一列除以 $\sqrt{2}$，第二列减去在第一列上的投影再除以长度，于是

$$\boldsymbol{q}_1 = \frac{1}{\sqrt{2}}(1,0,1)^{\top}, \qquad \boldsymbol{q}_2 = \frac{1}{\sqrt{6}}(-1,2,1)^{\top}.$$

极分解要用 $\boldsymbol{I}+\boldsymbol{\Delta}^{\top}\boldsymbol{\Delta}$ 的逆平方根。这个矩阵是

$$\boldsymbol{I}+\boldsymbol{\Delta}^{\top}\boldsymbol{\Delta} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix},$$

特征值为 $3, 1$，特征向量为 $(1,1)^{\top}/\sqrt{2}$ 和 $(1,-1)^{\top}/\sqrt{2}$，算出来的结果是

$$R^{\mathrm{pol}}_{\boldsymbol{X}}(\boldsymbol{\Delta}) \approx \begin{bmatrix} 0.7887 & -0.2113 \\ -0.2113 & 0.7887 \\ 0.5774 & 0.5774 \end{bmatrix}.$$

沿曲线 $R_{\boldsymbol{X}}(t\boldsymbol{\Delta})$ 算加速度的切向分量，极分解得到零，QR 回缩得到

$$\boldsymbol{P}_{\boldsymbol{X}}\boldsymbol{C}''(0) = \begin{bmatrix} 0 & -1 \\ 1 & 0 \\ 0 & 0 \end{bmatrix},$$

不是零，这印证了两者阶数的差别。

图 25.11画出两个结果。QR 分解保留第一列的方向，把调整都压给后面的列，极分解则两列对称地调整。两个新点张成同一个平面，这个事实在第 25.8节会派上用场。

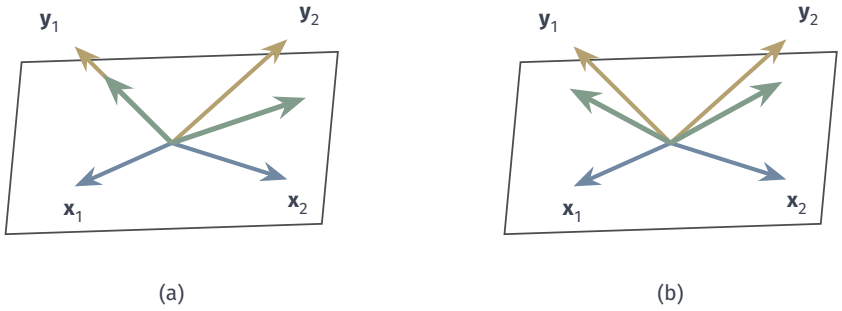


图 25.11　St(2, 3) 上的两种回缩。蓝箭头是当前两列，黄箭头是 $\boldsymbol{X}+\boldsymbol{\Delta}$ 的两列，绿箭头是回缩结果，方框是 $\boldsymbol{y}_1, \boldsymbol{y}_2$ 张成的平面。(a) QR 分解：第一列方向不变。(b) 极分解：两列对称调整。

回缩、指数映射与最近点　第三个候选是把 $\boldsymbol{x}+\boldsymbol{v}$ 投影到 M 上的最近点。球面上它恰好就是归一化；St(k, n) 上在 Frobenius 范数下恰好就是极分解，例中极分解结果到 $\boldsymbol{Y}$ 的距离约为 0.732，QR 结果约为 0.850。

但回缩并不要求求解最近点问题。QR 回缩不是最近点，同样满足定义，而且通常更便宜。在一般曲面上，最近点可能需要迭代才能算出，甚至不唯一。表 25.3比较三者。

表 25.3　三种回到流形的方式。“二阶”的结论对最近点投影要求流形足够光滑，表中代价按一次运算计。

方式	阶	球面	Stiefel
指数映射	二阶	$O(n)$	需矩阵指数
最近点投影	二阶	$O(n)$	需 SVD
QR 回缩	一阶	同归一化	约 $O(nk^2)$

25.1 流形上的优化问题
25.2 最优性与导数计算
25.3 迭代的几何运算
25.3.1 回缩
25.3.2 目标拉回
25.3.3 向量搬运
25.4 一阶方法
25.5 二阶方法
25.6 拟 Newton 法
25.7 黎曼信赖域
25.8 表示与计算成本
25.9 本章小结

25.3.2 目标拉回

把问题搬到同一个切空间 候选步是切空间中的向量，而目标定义在流形上。把两者复合，就得到切空间上的普通函数，这是后面评价候选步的唯一依据。

定义 25.4 拉回目标 在 $\boldsymbol{x} \in M$ 处，目标 f 的拉回（pullback）是切空间上的函数

$$\hat{f}_{\boldsymbol{x}}(\boldsymbol{v}) = f\big(R_{\boldsymbol{x}}(\boldsymbol{v})\big), \qquad \boldsymbol{v} \in U_{\boldsymbol{x}}. \tag{25.19}$$

这个定义的好处是，$\hat{f}_{\boldsymbol{x}}$ 活在线性空间上，前面各章的工具（Taylor 展开、Armijo 条件、预测下降）都可以直接使用。

贯穿例在 $\boldsymbol{x}^{(0)}$ 的切平面上取一组标准正交基：

$$\boldsymbol{E}_1 = \frac{1}{3}(1,-2,2)^{\top}, \qquad \boldsymbol{E}_2 = \frac{1}{3}(2,-1,-2)^{\top}.$$

可以检查 $\boldsymbol{x}^{(0)}, \boldsymbol{E}_1, \boldsymbol{E}_2$ 两两正交且长度为一。

沿 $\boldsymbol{v} = s\boldsymbol{E}_2$ 拉回。需要的内积是 $\boldsymbol{x}^{(0)\top}\boldsymbol{A}\boldsymbol{E}_2 = -\frac{8}{9}$ 和 $\boldsymbol{E}_2^{\top}\boldsymbol{A}\boldsymbol{E}_2 = \frac{22}{9}$，代入归一化回缩，得到

$$\hat{f}_{\boldsymbol{x}^{(0)}}(s\boldsymbol{E}_2) = \frac{1}{1+s^2}\cdot\frac{1}{2}\Big(\frac{16}{9} - \frac{16}{9}s + \frac{22}{9}s^2\Big) = \frac{8 - 8s + 11s^2}{9(1+s^2)}. \tag{25.20}$$

一阶与二阶变化 下面的引理说明，拉回在零点的一阶信息总是黎曼梯度，二阶信息则取决于回缩的加速度。

引理 25.5 拉回的导数 设 M 是嵌入子流形，取诱导度量，R 是回缩，$\boldsymbol{v} \in T_{\boldsymbol{x}}M$，$\boldsymbol{c}(t) = R_{\boldsymbol{x}}(t\boldsymbol{v})$。则

$$\nabla \hat{f}_{\boldsymbol{x}}(\boldsymbol{0}) = \operatorname{grad} f(\boldsymbol{x}), \tag{25.21}$$

$$\langle \boldsymbol{v}, \nabla^2 \hat{f}_{\boldsymbol{x}}(\boldsymbol{0})\boldsymbol{v}\rangle = \langle \boldsymbol{v}, \operatorname{Hess} f(\boldsymbol{x})[\boldsymbol{v}]\rangle + \big\langle \operatorname{grad} f(\boldsymbol{x}), \boldsymbol{c}''(0)\big\rangle. \tag{25.22}$$

证明 由复合函数求导和式 (25.15)，

$$\frac{\mathrm{d}}{\mathrm{d}t}\hat{f}_{\boldsymbol{x}}(t\boldsymbol{v})\Big|_{t=0} = \mathrm{d}f_{\boldsymbol{x}}[\boldsymbol{c}'(0)] = \mathrm{d}f_{\boldsymbol{x}}[\boldsymbol{v}] = \langle \operatorname{grad} f(\boldsymbol{x}), \boldsymbol{v}\rangle,$$

这是式 (25.21)。

$\hat{f}_{\boldsymbol{x}}(t\boldsymbol{v}) = f(\boldsymbol{c}(t))$，把式 (25.12)用到曲线 $\boldsymbol{c}$ 上，再用式 (25.13)替换第一项，就得到式 (25.22)。 ∎

式 (25.22)的附加项给出了两条实用的结论。第一，二阶回缩的 $\boldsymbol{c}''(0)$ 是法向的，黎曼梯度是切向的，附加项为零，拉回 Hessian 等于黎曼 Hessian。第二，在驻点上 $\operatorname{grad} f = \mathbf{0}$，对任何回缩附加项都为零，所以一般回缩在驻点处两者也相等。

一般回缩在非驻点处可能有差别。圆周的例子最容易看清。取角度 θ 为坐标，目标

$$\varphi(\theta) = \frac{1}{2}\big(\cos^2\theta + 4\sin^2\theta\big), \qquad \varphi'(\theta) = \frac{3}{2}\sin 2\theta, \qquad \varphi''(\theta) = 3\cos 2\theta.$$

比较三种回缩：指数映射 $\theta + s$，归一化 $\theta + \arctan s$，以及一个人为构造的一阶回缩 $\theta + s + \frac{1}{2}s^2$。第三个满足定义，但沿圆周的加速度是 1，不是二阶的。对它求拉回的二阶导数，得到

$$\hat{f}''(0) = \varphi''(\theta) + \varphi'(\theta).$$

在 $\theta = \pi/6$ 处，$\varphi' = 3\sqrt{3}/4 \approx 1.299$，$\varphi'' = 1.5$。前两种回缩的拉回二阶导数都是 1.5，第三种是 2.799。在驻点 $\theta = 0$ 处 $\varphi' = 0$，三者都是 3。图 25.12画出这个差别。

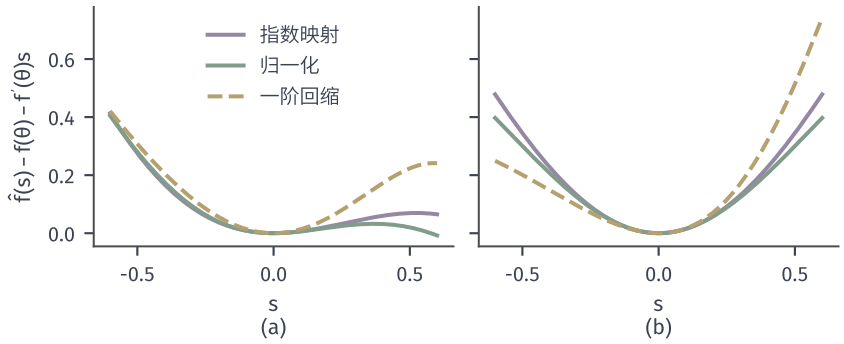


图 25.12 圆周上目标扣除一阶项后的拉回 $\hat{f}(s) - \varphi(\theta) - \varphi'(\theta)s$。紫线、绿线、黄虚线分别对应指数映射、归一化与一阶回缩 $\theta + s + s^2/2$。(a) 非驻点 $\theta = \pi/6$，黄虚线在零点的曲率明显更大。(b) 驻点 $\theta = 0$，三条曲线在零点处曲率相同。

用拉回评价候选步 式 (25.21)和式 (25.22)支持下面这个切空间二次模型：

$$m_{\boldsymbol{x}}(\boldsymbol{v}) = f(\boldsymbol{x}) + \langle \operatorname{grad} f(\boldsymbol{x}), \boldsymbol{v}\rangle + \frac{1}{2}\langle \boldsymbol{v}, \operatorname{Hess} f(\boldsymbol{x})[\boldsymbol{v}]\rangle. \tag{25.23}$$

在贯穿例的方向上核对。沿 $s\boldsymbol{E}_2$，切向曲率是

$$\langle \boldsymbol{E}_2, (\boldsymbol{A} - q\boldsymbol{I})\boldsymbol{E}_2\rangle = \frac{22}{9} - \frac{16}{9} = \frac{2}{3},$$

25.1 流形上的优化问题
25.2 最优性与导数计算
25.3 迭代的几何运算
25.3.1 回缩
25.3.2 目标拉回
25.3.3 向量搬运
25.4 一阶方法
25.5 二阶方法
25.6 拟 Newton 法
25.7 黎曼信赖域
25.8 表示与计算成本
25.9 本章小结

模型是

$$m(s\boldsymbol{E}_2) = \frac{8}{9} - \frac{8}{9}s + \frac{1}{3}s^2.$$

用式 (25.20)减去模型，分子通分后得到

$$\hat{f}_{\boldsymbol{x}^{(0)}}(s\boldsymbol{E}_2) - m(s\boldsymbol{E}_2) = \frac{8s^3 - 3s^4}{9(1+s^2)}.$$

误差是 s^3 量级，这正是二阶回缩的效果。$s = 0.1$ 时误差约为 8.5×10^{-4}，$s = 1$ 时误差是 $\frac{5}{18}$，模型已不可信，这是信赖域要处理的问题。

25.3.3 向量搬运

为什么需要搬运 共轭梯度要把上一轮的方向和当前梯度相加，拟 Newton 要算两点梯度之差。欧氏空间里这些都是普通的加减法，流形上却有一个类型错误：旧向量在 $T_{\boldsymbol{x}}M$ 中，新向量在 $T_{\boldsymbol{y}}M$ 中，两者属于不同的线性空间。

在球面上，不同点的切平面是不同的平面，直接相加得到的向量一般不再切于任何一点。例如 $\boldsymbol{x}^{(0)}$ 和 $\boldsymbol{x}^{(1)}$ 处的两个切向量之和，通常与 $\boldsymbol{x}^{(1)}$ 有非零内积。需要先把旧向量搬到新切空间。

定义 25.6 向量搬运 伴随回缩 R 的**向量搬运**（vector transport）是一族映射，对 $\boldsymbol{x} \in M$ 和 $\boldsymbol{\eta} \in T_{\boldsymbol{x}}M$ 给出线性映射 $\mathcal{T}_{\boldsymbol{\eta}}$，它把 $T_{\boldsymbol{x}}M$ 映到点 $R_{\boldsymbol{x}}(\boldsymbol{\eta})$ 的切空间，且随 $(\boldsymbol{x}, \boldsymbol{\eta})$ 光滑变化，并满足 $\mathcal{T}_{\boldsymbol{0}} = \mathrm{id}$。

定义只要求三件事：结果落在新切空间中（一致性），对被搬运的向量是线性的，零步时什么也不做。它不要求保持长度和内积。后面需要这些额外性质时，要逐个核对。为了书写简洁，起点 $\boldsymbol{x}$、终点 $\boldsymbol{y} = R_{\boldsymbol{x}}(\boldsymbol{\eta})$ 明确时，记成 $\mathcal{T}_{\boldsymbol{x}\to\boldsymbol{y}}$。

三种具体搬运 第一种是**投影搬运**（projection transport），把旧向量看作环境空间的向量，投影到新切空间：

$$\mathcal{T}^{\mathrm{P}}_{\boldsymbol{x}\to\boldsymbol{y}}(\boldsymbol{v}) = \boldsymbol{P}_{\boldsymbol{y}}\boldsymbol{v}. \tag{25.24}$$

它只对嵌入子流形可用，计算便宜。正交投影不会增加长度，但一般会减小长度。

第二种是**平行移动**（parallel transport），即卷四定义的沿曲线协变导数为零的搬运，它是等距的。球面上沿大圆从 $\boldsymbol{x}$ 到 $\boldsymbol{y}$ 有闭式：

$$\mathcal{T}^{\parallel}_{\boldsymbol{x}\to\boldsymbol{y}}(\boldsymbol{v}) = \boldsymbol{v} - \frac{\langle \boldsymbol{x}+\boldsymbol{y}, \boldsymbol{v}\rangle}{1+\langle \boldsymbol{x}, \boldsymbol{y}\rangle}(\boldsymbol{x}+\boldsymbol{y}). \tag{25.25}$$

这里要求 $\boldsymbol{y} \neq -\boldsymbol{x}$。

下面验证结果确实切于 $\boldsymbol{y}$ 且长度不变。记

$$c = \langle \boldsymbol{x}, \boldsymbol{y} \rangle, \qquad a = \langle \boldsymbol{x} + \boldsymbol{y}, \boldsymbol{v} \rangle.$$

由 $\boldsymbol{v} \perp \boldsymbol{x}$ 有 $\langle \boldsymbol{y}, \boldsymbol{v} \rangle = a$，又 $\langle \boldsymbol{x} + \boldsymbol{y}, \boldsymbol{y} \rangle = 1 + c$，于是

$$\langle \boldsymbol{y}, \mathcal{T}^{\parallel}\boldsymbol{v} \rangle = a - \frac{a}{1+c}(1+c) = 0.$$

再用 $\|\boldsymbol{x} + \boldsymbol{y}\|_2^2 = 2 + 2c$ 算长度：

$$\|\mathcal{T}^{\parallel}\boldsymbol{v}\|_2^2 = \|\boldsymbol{v}\|_2^2 - \frac{2a^2}{1+c} + \frac{a^2(2+2c)}{(1+c)^2} = \|\boldsymbol{v}\|_2^2.$$

第三种是**微分回缩**（differentiated retraction），直接用回缩曲线的速度：

$$\mathcal{T}^{\mathrm{D}}_{\boldsymbol{\eta}}(\boldsymbol{v}) = \frac{\mathrm{d}}{\mathrm{d}t} R_{\boldsymbol{x}}(\boldsymbol{\eta} + t\boldsymbol{v})\Big|_{t=0}.$$

它的好处是下一节的线搜索导数恰好用这个向量。球面归一化沿搜索方向 $\boldsymbol{d}$，设 $\boldsymbol{y} = R_{\boldsymbol{x}}(\alpha\boldsymbol{d})$，$r = \|\boldsymbol{x} + \alpha\boldsymbol{d}\|_2$，求导得到

$$\frac{\mathrm{d}}{\mathrm{d}\tau} R_{\boldsymbol{x}}\big((\alpha+\tau)\boldsymbol{d}\big)\Big|_{\tau=0} = \frac{1}{r}\boldsymbol{P}_{\boldsymbol{y}}\boldsymbol{d}.$$

所以此时投影搬运与微分回缩只差一个正的倍数 r。

搬运结果的比较　图 25.13对比了切向量在两点之间的搬运。把 $\boldsymbol{v}$ 平移到 $\boldsymbol{y}$ 得到的副本并不切于球面（灰色虚线）。投影把副本垂直压到切平面上，长度变短；平行移动沿大圆旋转切平面，长度不变。

25.1 流形上的优化问题
25.2 最优性与导数计算
25.3 迭代的几何运算
25.4 一阶方法
25.4.1 黎曼梯度下降
25.4.2 黎曼共轭梯度
25.5 二阶方法
25.6 拟 Newton 法
25.7 黎曼信赖域
25.8 表示与计算成本
25.9 本章小结

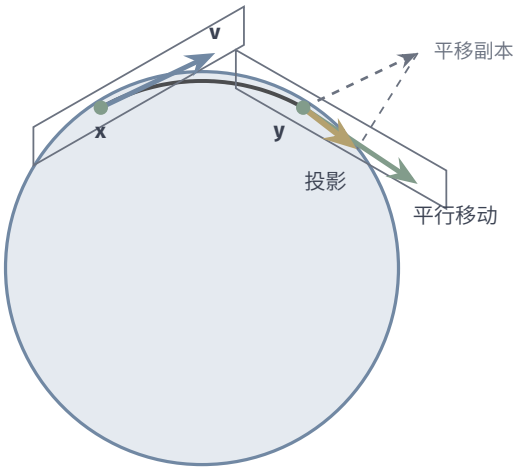


图 25.13 把切向量 $\boldsymbol{v}$（蓝）从 $\boldsymbol{x}$ 搬到 $\boldsymbol{y}$。深灰弧是连接两点的大圆，两个方框是切平面。灰色虚线箭头是平移的副本，不切于球面。黄箭头是投影结果，长度缩短；绿箭头是平行移动结果，长度与 $\boldsymbol{v}$ 相同。

用贯穿例算一次。第 25.4.1节将得到 $\boldsymbol{x}^{(1)} \approx (0.8418, 0.5388, -0.0337)^{\top}$，它与起点的内积约为 0.9091。把基向量 $\boldsymbol{E}_1, \boldsymbol{E}_2$ 搬到 $\boldsymbol{x}^{(1)}$，投影的结果范数约为 0.9949 和 0.9147，内积约为 0.0408，平行移动的结果仍是标准正交的。

投影缩短的量取决于向量与连线方向的夹角。沿大圆方向的向量缩短最多，缩短比例等于两点内积。负梯度方向恰好是大圆方向，$\|\boldsymbol{g}^{(0)}\|_2 \approx 0.9162$ 的向量投影后长度约为 0.8330，比值 0.9091。

因此投影搬运不是等距的：它让向量落进了新切空间，但没有保持内积。若 $\boldsymbol{y} \perp \boldsymbol{x}$，投影还会把沿连线方向的向量压成零，这时映射不可逆。表 25.4列出后面的算法需要核对的性质。

表 25.4 三种搬运的性质，以球面归一化回缩为例。可逆一栏的 $c = \langle \boldsymbol{x}, \boldsymbol{y} \rangle$；一般流形上的平行移动要解常微分方程。

搬运	长度	可逆	代价
投影	一般缩短	需 $c \neq 0$	$O(n)$
平行移动	保持	是	$O(n)$
微分回缩	沿步方向缩到 $1/r^2$ 倍	需 $c \neq 0$	$O(n)$

25.4 一阶方法

三种几何运算齐备后，先看只用一阶信息的方法。于是要问：负切向梯度加回缩为什么能下降，步长如何选择，以及搬运历史方向怎样加快收敛又带来了哪些新的检查项？

25.1 流形上的优化问题
25.2 最优性与导数计算
25.3 迭代的几何运算
25.4 一阶方法
25.4.1 黎曼梯度下降
25.4.2 黎曼共轭梯度
25.5 二阶方法
25.6 拟 Newton 法
25.7 黎曼信赖域
25.8 表示与计算成本
25.9 本章小结

25.4.1 黎曼梯度下降

主要思想 黎曼梯度下降（Riemannian gradient descent）在当前切空间中沿负梯度取步，再用回缩回到流形：

$$\boldsymbol{x}^{(t+1)} = R_{\boldsymbol{x}^{(t)}}\big(-\alpha^{(t)}\boldsymbol{g}^{(t)}\big), \qquad \boldsymbol{g}^{(t)} = \operatorname{grad} f(\boldsymbol{x}^{(t)}). \tag{25.26}$$

为什么这一步能下降？记 $\phi(\alpha) = \hat{f}_{\boldsymbol{x}}(-\alpha\boldsymbol{g})$，这是一个普通的一元函数。由式 (25.21)，

$$\phi'(0) = \langle \operatorname{grad} f(\boldsymbol{x}), -\boldsymbol{g}\rangle = -\|\boldsymbol{g}\|_2^2 < 0.$$

所以只要 $\boldsymbol{g} \neq \boldsymbol{0}$，足够小的步长一定使目标下降。这个结论只用了回缩的一阶一致性，不需要二阶回缩。

步长的选择与欧氏情形完全平行，只是把比较对象换成拉回函数。Armijo 条件要求

$$f\big(R_{\boldsymbol{x}}(-\alpha\boldsymbol{g})\big) \le f(\boldsymbol{x}) - c_1\alpha\|\boldsymbol{g}\|_2^2. \tag{25.27}$$

下降的检验必须针对回缩后的点，切平面上的点 $\boldsymbol{x} - \alpha\boldsymbol{g}$ 根本不可行，其函数值没有意义。

变量

- $\boldsymbol{x}^{(t)} \in \mathbb{R}^3$：球面上的当前点，长度为一。
- $q^{(t)}$：Rayleigh 商的取值，标量。
- $\boldsymbol{g}^{(t)}$：黎曼梯度，与 $\boldsymbol{x}^{(t)}$ 垂直的三维向量。
- α：当前试探步长；$c_1 = \tfrac{1}{4}$ 是 Armijo 常数，缩减因子取 $\tfrac{1}{2}$。

初始化 取 $\boldsymbol{x}^{(0)}$，初始试探步长 $\alpha_0 = 1$，停止容差 $\|\boldsymbol{g}^{(t)}\|_2 \le 10^{-6}$。例中 $\boldsymbol{x}^{(0)} = \tfrac{1}{3}(2,2,1)^{\top}$，$f(\boldsymbol{x}^{(0)}) = \tfrac{8}{9}$。

每轮更新

1. 由式 (25.7)算 $\boldsymbol{g}^{(t)}$。例中第 0 轮已算得

$$\boldsymbol{g}^{(0)} = \frac{1}{27}(-14,4,20)^{\top}, \qquad \|\boldsymbol{g}^{(0)}\|_2^2 = \frac{68}{81}.$$

2. 令 $\alpha = \alpha_0$，按式 (25.14)算试探点，并检验式 (25.27)，不满足时 α 减半。例中第 0 轮先试 $\alpha = 1$：

$$\boldsymbol{x}^{(0)} - \boldsymbol{g}^{(0)} = \frac{1}{27}(32,14,-11)^{\top}.$$

归一化后的点是 $(0.8738, 0.3823, -0.3004)^{\mathsf{T}}$，目标值 0.7084，下降 0.1805，低于要求的 $\frac{1}{4}\cdot\frac{68}{81}\approx 0.2099$，拒绝。

3. 例中减半后试 $\alpha=\frac{1}{2}$，得到

$$\boldsymbol{x}^{(0)}-\tfrac{1}{2}\boldsymbol{g}^{(0)}=\frac{1}{27}(25,16,-1)^{\mathsf{T}}.$$

由勾股定理，长度的平方是 $1+\frac{1}{4}\cdot\frac{68}{81}=\frac{98}{81}$，长度是 $\frac{7\sqrt{2}}{9}$。

4. 接受时令 $\boldsymbol{x}^{(t+1)}$ 为该试探点。例中

$$\boldsymbol{x}^{(1)}=\frac{(25,16,-1)^{\mathsf{T}}}{21\sqrt{2}}\approx(0.8418,0.5388,-0.0337)^{\mathsf{T}}.$$

目标值 0.6468，下降 0.2421，超过要求的 0.1049，接受。

图 25.14画出这一轮的几何：两个候选点都在切平面上，沿径向回到球面后才可以比较。

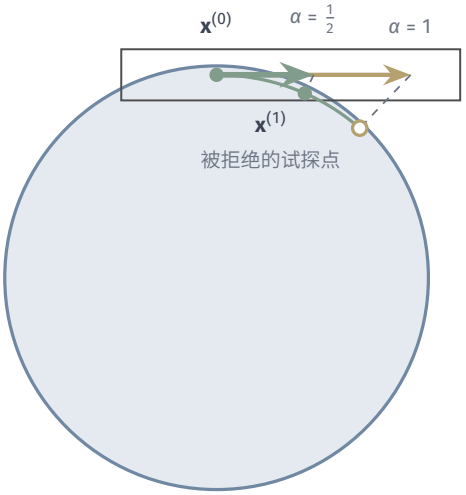


图 25.14　第 0 轮迭代的几何，视线接近垂直于 $\boldsymbol{x}^{(0)}$ 与 $\boldsymbol{g}^{(0)}$ 所在的平面。方框是切平面的一块，黄箭头和绿箭头分别是 $\alpha=1$ 和 $\alpha=\frac{1}{2}$ 的切向步，虚线是归一化回缩。空心点未通过 Armijo 检验，绿点 $\boldsymbol{x}^{(1)}$ 通过。

第 1 轮算得

$$\boldsymbol{g}^{(1)}\approx(-0.2472,0.3805,-0.0911)^{\mathsf{T}},\qquad \|\boldsymbol{g}^{(1)}\|_2^2\approx 0.2142.$$

$\alpha=1$ 的试探点是 $(0.9883, 0.1436, 0.0521)^{\mathsf{T}}$，目标值 0.5144，下降 0.1324，超过要求的 0.0536，接受。

第 2 轮 $\|\boldsymbol{g}^{(2)}\|_2^2 \approx 0.0443$。$\alpha = 1$ 的试探点目标值 0.5152，反而上升，拒绝；$\alpha = \frac{1}{2}$ 的试探点目标值 0.5036，下降 0.0107，超过要求的 0.0055，接受。表 25.5汇总前几轮。

表 25.5　贯穿例的黎曼梯度下降，回溯线搜索。

t	$\boldsymbol{x}^{(t)}$	$f(\boldsymbol{x}^{(t)})$	$\|\boldsymbol{g}^{(t)}\|_2$	接受的 α
0	$(0.6667, 0.6667, 0.3333)$	0.8889	0.9162	0.5
1	$(0.8418, 0.5388, -0.0337)$	0.6468	0.4628	1
2	$(0.9883, 0.1436, 0.0521)$	0.5144	0.2104	0.5
3	$(0.9970, 0.0735, -0.0252)$	0.5036	0.1051	0.5
4	$(0.9992, 0.0369, 0.0125)$	0.5009	0.0526	0.5

末尾几轮梯度范数每轮减半。这有明确的来由：$\boldsymbol{e}_1$ 处切向曲率是 1 和 3，局部迭代相当于 $\boldsymbol{v} \mapsto (\boldsymbol{I} - \alpha\boldsymbol{H})\boldsymbol{v}$，$\alpha = \frac{1}{2}$ 时两个因子是 $\frac{1}{2}$ 和 $-\frac{1}{2}$。这也解释了第三个坐标的符号交替。当 $\|\boldsymbol{g}^{(t)}\|_2 \le 10^{-6}$ 时停止，最终得到 $\boldsymbol{x}^{(T)} \approx \boldsymbol{e}_1$。

图 25.15是球面上的路径，图 25.16是收敛曲线。固定步长 $\alpha = \frac{2}{9}$ 的路径更平缓，但每轮的收缩因子是 $1 - \frac{2}{9} = \frac{7}{9}$，慢得多。

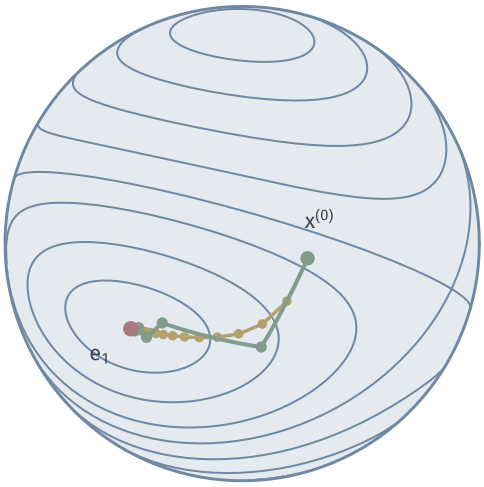


图 25.15　球面上的迭代路径，蓝线是目标的等高线。绿色为回溯线搜索（$c_1 = \frac{1}{4}$），黄色为固定步长 $\alpha = \frac{2}{9}$，点之间用大圆弧连接，红点是极小点。

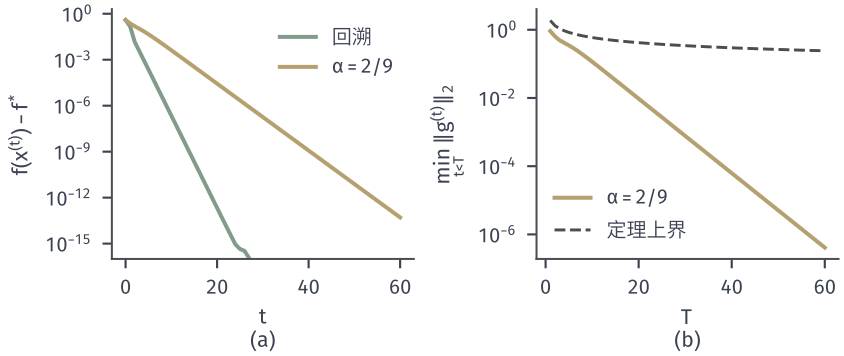


图 25.16 贯穿例上的收敛。(a) 目标误差，绿色回溯，黄色固定步长 $\frac{2}{9}$。(b) 固定步长下至第 T 轮为止的最小梯度范数（黄）与定理 25.7给出的上界（灰虚线，$L = \frac{9}{2}$）。上界有效，但对这个问题偏松。

收敛性 欧氏分析的关键是下降引理，流形上只需要把它改写成对拉回函数的假设。这个假设是下面的上界，称为拉回的 L 光滑性：对所考虑的 $\boldsymbol{x}$ 和 $\boldsymbol{v}$，

$$f(R_{\boldsymbol{x}}(\boldsymbol{v})) \le f(\boldsymbol{x}) + \langle \operatorname{grad} f(\boldsymbol{x}), \boldsymbol{v} \rangle + \frac{L}{2}\|\boldsymbol{v}\|_2^2. \tag{25.28}$$

定理 25.7 黎曼梯度下降的残差界 设 f 在 M 上有下界 $f^\star$，并且式 (25.28)对所有 $\boldsymbol{x} \in M$ 和 $\boldsymbol{v} \in T_{\boldsymbol{x}}M$ 成立。取固定步长 $\alpha = 1/L$，则

$$\min_{0 \le t < T} \|\boldsymbol{g}^{(t)}\|_2 \le \sqrt{\frac{2L\big(f(\boldsymbol{x}^{(0)}) - f^\star\big)}{T}}. \tag{25.29}$$

改用初始步长 α_0、缩减因子 $\beta \in (0,1)$ 的 Armijo 回溯时，接受的步长不小于

$$\underline{\alpha} = \min\Big\{\alpha_0,\ \frac{2\beta(1-c_1)}{L}\Big\}, \tag{25.30}$$

每轮下降至少 $c_1 \underline{\alpha} \|\boldsymbol{g}^{(t)}\|_2^2$。

证明 取 $\boldsymbol{v} = -\alpha \boldsymbol{g}^{(t)}$ 代入式 (25.28)，$\alpha = 1/L$ 时得到

$$f(\boldsymbol{x}^{(t+1)}) \le f(\boldsymbol{x}^{(t)}) - \frac{1}{L}\|\boldsymbol{g}^{(t)}\|_2^2 + \frac{1}{2L}\|\boldsymbol{g}^{(t)}\|_2^2 = f(\boldsymbol{x}^{(t)}) - \frac{1}{2L}\|\boldsymbol{g}^{(t)}\|_2^2.$$

对 $t = 0, \dots, T-1$ 求和，左边相消，再用 $f(\boldsymbol{x}^{(T)}) \ge f^\star$，于是

$$\frac{1}{2L}\sum_{t=0}^{T-1} \|\boldsymbol{g}^{(t)}\|_2^2 \le f(\boldsymbol{x}^{(0)}) - f^\star.$$

和式不小于 T 乘最小项，整理得式 (25.29)。

再看回溯。由式 (25.28)，只要 $\alpha \le 2(1-c_1)/L$，就有

$$f(R_{\boldsymbol{x}}(-\alpha \boldsymbol{g})) \le f(\boldsymbol{x}) - \alpha\Big(1 - \frac{L\alpha}{2}\Big)\|\boldsymbol{g}\|_2^2 \le f(\boldsymbol{x}) - c_1\alpha\|\boldsymbol{g}\|_2^2,$$

Armijo 条件成立。若初始步长被拒绝，则最后一次被拒绝的步长大于 $2(1-c_1)/L$，接受的步长至少是它的 β 倍，所以接受的步长不小于 $\underline{\alpha}$。 ■

定理的结论是梯度范数变小，这里的量不是到极小点的距离，也没有说收敛到全局极小。常数 L 依赖回缩：同一目标换一个回缩，上界 (25.28)中的常数也要重新估计。

对紧流形、光滑目标和光滑回缩，式 (25.28)在切向量长度有上界的范围内自动成立，因为拉回的二阶导数在紧集上有界。贯穿例的归一化回缩可以把常数算出来，而且不限长度。

引理 25.8　球面 Rayleigh 商的光滑常数　设 $\boldsymbol{A}$ 对称，最小、最大特征值为 λ_1, λ_n，$f(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{x}$，回缩为式 (25.14)。则式 (25.28)对所有 $\boldsymbol{x} \in S^{n-1}$，$\boldsymbol{v} \perp \boldsymbol{x}$ 成立，常数可取

$$L = \frac{3}{2}(\lambda_n - \lambda_1). \tag{25.31}$$

证明　记 $s = \|\boldsymbol{v}\|_2^2$。因为 $\boldsymbol{v} \perp \boldsymbol{x}$，切向梯度与 $\boldsymbol{v}$ 的内积等于 $\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{v}$。把回缩代入后通分，得到

$$f(R_{\boldsymbol{x}}(\boldsymbol{v})) - f(\boldsymbol{x}) - \langle \boldsymbol{g}, \boldsymbol{v}\rangle = \frac{\frac{1}{2}\boldsymbol{v}^{\top}\boldsymbol{A}\boldsymbol{v} - \frac{1}{2}qs - s\,\boldsymbol{x}^{\top}\boldsymbol{A}\boldsymbol{v}}{1+s}.$$

分子前两项满足

$$\frac{1}{2}\boldsymbol{v}^{\top}\boldsymbol{A}\boldsymbol{v} - \frac{1}{2}qs \le \frac{1}{2}(\lambda_n - \lambda_1)s,$$

这里用了 $\boldsymbol{v}^{\top}\boldsymbol{A}\boldsymbol{v} \le \lambda_n s$，$q \ge \lambda_1$。分母不小于一，这一部分的贡献不超过 $\frac{1}{2}(\lambda_n - \lambda_1)s$。

第三项用 Cauchy–Schwarz 不等式和 $\sqrt{s}/(1+s) \le \frac{1}{2}$，得到

$$\frac{s\,|\langle \boldsymbol{g}, \boldsymbol{v}\rangle|}{1+s} \le s\|\boldsymbol{g}\|_2 \frac{\sqrt{s}}{1+s} \le \frac{1}{2}\|\boldsymbol{g}\|_2\, s.$$

25.1 流形上的优化问题
25.2 最优性与导数计算
25.3 迭代的几何运算
25.4 一阶方法
25.4.1 黎曼梯度下降
25.4.2 黎曼共轭梯度
25.5 二阶方法
25.6 拟 Newton 法
25.7 黎曼信赖域
25.8 表示与计算成本
25.9 本章小结

最后界住梯度。因为 $(\boldsymbol{A}-\lambda_1\boldsymbol{I})(\lambda_n\boldsymbol{I}-\boldsymbol{A})$ 半正定，在 $\boldsymbol{x}$ 上取二次型并整理，得到

$$\|\boldsymbol{g}\|_2^2=\boldsymbol{x}^{\top}\boldsymbol{A}^2\boldsymbol{x}-q^2\le(q-\lambda_1)(\lambda_n-q)\le\Big(\frac{\lambda_n-\lambda_1}{2}\Big)^2.$$

把三部分合并，上界是

$$\frac{1}{2}(\lambda_n-\lambda_1)s+\frac{1}{4}(\lambda_n-\lambda_1)s=\frac{1}{2}Ls,\qquad L=\frac{3}{2}(\lambda_n-\lambda_1),$$

这正是式 (25.28)所需的形式。 ■

贯穿例中 $\lambda_n-\lambda_1=3$，所以 $L=\frac{9}{2}$，$1/L=\frac{2}{9}$，这是图中固定步长的来历。随机采样 20 万组 $(\boldsymbol{x},\boldsymbol{v})$，式 (25.28)所需常数的最大值约为 2.98，说明这个界偏保守，但安全。

每轮成本 梯度、投影和回缩的每轮代价应当一起计算。球面上一次 $\boldsymbol{A}$ 乘向量算出 $\boldsymbol{g}^{(t)}$，投影和归一化都是 $O(n)$，线搜索的每次试探还要一次目标计算。若 $\boldsymbol{A}$ 是大规模稀疏矩阵，主要开销就是 $\boldsymbol{A}$ 乘向量。$\mathrm{St}(k,n)$ 上每轮要做 $\boldsymbol{AX}$、投影和 $O(nk^2)$ 的 QR 分解，k 较大时回缩的比重不能忽略。

25.4.2 黎曼共轭梯度

主要思想 第 6章的非线性共轭梯度把上一轮方向与当前负梯度相加，得到比负梯度更好的方向。流形上上一轮方向 $\boldsymbol{d}^{(t)}$ 在 $T_{\boldsymbol{x}^{(t)}}M$ 中，需要先搬到新切空间。**黎曼共轭梯度**（Riemannian conjugate gradient）的方向更新是

$$\boldsymbol{d}^{(t+1)}=-\boldsymbol{g}^{(t+1)}+\beta^{(t+1)}\mathcal{T}_{\boldsymbol{x}^{(t)}\to\boldsymbol{x}^{(t+1)}}\big(\boldsymbol{d}^{(t)}\big).\tag{25.32}$$

系数 β 也要用同一切空间中的量。Fletcher–Reeves 形式只用两个梯度的范数，范数是各自切空间内算的，不需要搬运：

$$\beta_{\mathrm{FR}}^{(t+1)}=\frac{\|\boldsymbol{g}^{(t+1)}\|_2^2}{\|\boldsymbol{g}^{(t)}\|_2^2}.\tag{25.33}$$

Polak–Ribière 形式要算梯度之差，旧梯度必须先搬过去：

$$\beta_{\mathrm{PR}}^{(t+1)}=\frac{\big\langle\boldsymbol{g}^{(t+1)},\,\boldsymbol{g}^{(t+1)}-\mathcal{T}_{\boldsymbol{x}^{(t)}\to\boldsymbol{x}^{(t+1)}}(\boldsymbol{g}^{(t)})\big\rangle}{\|\boldsymbol{g}^{(t)}\|_2^2}.\tag{25.34}$$

实际常取 $\max\{0,\beta_{\mathrm{PR}}\}$，这称为 PR+，系数为零时自动回到负梯度方向。

变量

- $\boldsymbol{x}^{(t)}$、$\boldsymbol{g}^{(t)}$：当前点与黎曼梯度，均为三维向量。
- $\boldsymbol{d}^{(t)}$：搜索方向，切于 $\boldsymbol{x}^{(t)}$。
- $\widetilde{\boldsymbol{d}}$：上一轮方向搬运到新切空间后的向量。
- β：组合系数；线搜索常数 $c_1 = \tfrac{1}{4}$，试探步长从 1 开始减半。

初始化 令 $\boldsymbol{d}^{(0)} = -\boldsymbol{g}^{(0)}$，搬运取投影 (25.24)。例中第 0 轮与梯度下降相同，接受 $\alpha = \tfrac{1}{2}$，得到 $\boldsymbol{x}^{(1)}$。

每轮更新

1. 用式 (25.27)的形式沿 $\boldsymbol{d}^{(t)}$ 回溯，把右端的 $-\|\boldsymbol{g}\|_2^2$ 换成 $\langle \boldsymbol{g}^{(t)}, \boldsymbol{d}^{(t)} \rangle$，得到 $\boldsymbol{x}^{(t+1)}$。

2. 计算新梯度。例中第 1 轮

$$\boldsymbol{g}^{(1)} \approx (-0.2472,\, 0.3805,\, -0.0911)^{\top}.$$

3. 由式 (25.24)搬运旧方向。例中 $\boldsymbol{d}^{(0)} = -\boldsymbol{g}^{(0)}$，

$$\widetilde{\boldsymbol{d}} = \boldsymbol{P}_{\boldsymbol{x}^{(1)}} \boldsymbol{d}^{(0)} \approx (0.1973,\, -0.3537,\, -0.7279)^{\top}.$$

4. 由式 (25.33)算系数。例中

$$\beta_{\mathrm{FR}}^{(1)} = \frac{0.2142}{0.8395} \approx 0.2552.$$

5. 由式 (25.32)组合新方向。例中

$$\boldsymbol{d}^{(1)} \approx (0.2975,\, -0.4708,\, -0.0946)^{\top}.$$

6. 检查下降性：若 $\langle \boldsymbol{g}^{(t+1)}, \boldsymbol{d}^{(t+1)} \rangle \geq 0$，重启，令 $\boldsymbol{d}^{(t+1)} = -\boldsymbol{g}^{(t+1)}$。例中内积约为 $-0.2441 < 0$，不需要重启。

例中第 1 轮沿 $\boldsymbol{d}^{(1)}$ 试 $\alpha = 1$，得到 $\boldsymbol{x}^{(2)} \approx (0.9920,\, 0.0592,\, -0.1117)^{\top}$，目标值 0.5205，下降 0.1264，超过要求的 0.0610，接受。

第 2 轮算得 $\beta_{\mathrm{FR}}^{(2)} \approx 0.5326$，方向 $\boldsymbol{d}^{(2)} \approx (0.0523,\, -0.3163,\, 0.2967)^{\top}$。$\alpha = 1$ 和 $\alpha = \tfrac{1}{2}$ 都未通过，$\alpha = \tfrac{1}{4}$ 通过，得到目标值 0.5023。当 $\|\boldsymbol{g}^{(t)}\|_2 \leq 10^{-6}$ 时结束，最终得到 $\boldsymbol{x}^{(T)} \approx \pm \boldsymbol{e}_1$。

三维问题上共轭梯度几乎没有优势：例中第 2 轮的目标值 0.5205 还略高于梯度下降的 0.5144。历史方向的收益要在维数更高、条件数更大的问

题上才显现。图 25.17取 $n = 200$ 的问题，迭代到 $\|\boldsymbol{g}\|_2 \le 10^{-6}$ 为止，使用精确的拉回线搜索，PR+ 用了约 158 轮，FR 用了约 284 轮。

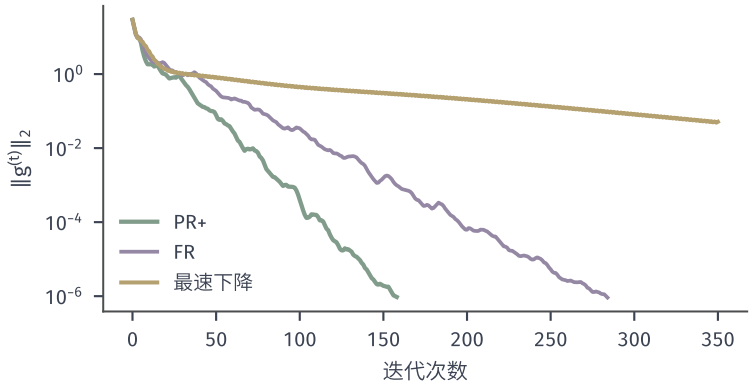


图 25.17　$n = 200$，$\boldsymbol{A}$ 的特征值在 1 到 100 之间等距，随机起点固定，球面上沿拉回函数作精确线搜索，用投影搬运。绿、紫分别为 PR+ 与 FR，黄色为最速下降。纵轴是黎曼梯度范数，最速下降在 350 轮内远未达到容差。

需要核对的条件　欧氏共轭梯度的保证不能直接照搬，有四项需要逐一核对。第一是方向的下降性。对式 (25.32)与 $\boldsymbol{g}^{(t+1)}$ 作内积，得到

$$\langle \boldsymbol{g}^{(t+1)}, \boldsymbol{d}^{(t+1)} \rangle = -\|\boldsymbol{g}^{(t+1)}\|_2^2 + \beta^{(t+1)} \langle \boldsymbol{g}^{(t+1)}, \mathcal{T}(\boldsymbol{d}^{(t)}) \rangle .$$

右端第二项若为正且较大，方向就不是下降方向。

第二是线搜索与搬运是否配套。欧氏情形下强 Wolfe 条件控制的正是 $\langle \boldsymbol{g}^{(t+1)}, \boldsymbol{d}^{(t)} \rangle$ 的大小。流形上线搜索控制的是一元函数的导数

$$\phi'(\alpha) = \big\langle \boldsymbol{g}^{(t+1)}, \mathcal{T}^{\mathrm{D}}_{\alpha \boldsymbol{d}}(\boldsymbol{d}) \big\rangle ,$$

它使用的是微分回缩。若方向更新用了另一种搬运，线搜索就控制不到上式第二项。

球面归一化时这个问题比较简单：第 25.3.3节已指出投影搬运只差一个正因子 r。例中 $\langle \boldsymbol{g}^{(1)}, \widetilde{\boldsymbol{d}} \rangle \approx -0.1171$，而 $r = \frac{7\sqrt{2}}{9}$，所以 $\phi'(\frac{1}{2}) \approx -0.1064$。这个配套关系是例子的特殊之处，一般不成立。

第三是搬运的范数。关于 FR 的全局收敛分析通常要求搬运后的方向不比原方向长，否则可以用一个缩放因子修正。投影搬运满足这一点，平行移动也满足。证明需要把 Zoutendijk 型的求和论证搬到流形上，篇幅较长，读者可查阅关于黎曼共轭梯度收敛的专门文献。其结论大意是：强 Wolfe 条件和不增长的搬运使 FR 方向保持下降，并且 $\liminf_{t\to\infty} \|\boldsymbol{g}^{(t)}\|_2 = 0$。

第四是重启。一方面下降性检查失败时需要重启；另一方面在非二次目标上旧方向会过时，常用的做法是每隔 $\dim M$ 轮或连续两轮梯度明显不

正交时重启。FR、PR+、搬运、线搜索的组合不同，保证也不同，任意组合不能默认继承欧氏结论。

25.1 流形上的优化问题
25.2 最优性与导数计算
25.3 迭代的几何运算
25.4 一阶方法
25.5 二阶方法
25.5.1 黎曼 Newton 法
25.5.2 阻尼与非精确求解
25.6 拟 Newton 法
25.7 黎曼信赖域
25.8 表示与计算成本
25.9 本章小结

25.5 二阶方法

一阶方法在贯穿例上每轮把误差减半，曲率矩阵的条件数变大时会更慢。切空间里的曲率信息能否换来一个更准确的步？接下来要弄清：这个线性子问题怎样写出，什么时候它的解值得采用？

需要分清三个判断，它们常常被混为一谈。模型非退化说的是线性子问题有唯一解，方向下降说的是这个解确实使目标减小，局部极小说的是所趋向的点是极小点。表 25.6用第 7章的语言把它们并列。

表 25.6 曲率算子的三种判断，$\boldsymbol{H}$ 是当前点的黎曼 Hessian。

判断	条件	不保证什么
模型非退化	$\boldsymbol{H}$ 可逆	解是下降方向
方向下降	$\boldsymbol{H}$ 在切空间上正定即可	趋向极小点的全局性
局部极小	驻点处 $\boldsymbol{H}$ 正定	全局极小

25.5.1 黎曼 Newton 法

主要思想 由第 25.3.2节, 模型 (25.23)是拉回函数在零点的二阶近似。令模型的梯度为零, 就得到切空间内的线性方程, **黎曼 Newton 法**（Riemannian Newton method）解这个方程再回缩：

$$\operatorname{Hess} f(\boldsymbol{x}^{(t)})[\boldsymbol{v}^{(t)}] = -\boldsymbol{g}^{(t)}, \quad \boldsymbol{v}^{(t)} \in T_{\boldsymbol{x}^{(t)}}M, \qquad \boldsymbol{x}^{(t+1)} = R_{\boldsymbol{x}^{(t)}}(\boldsymbol{v}^{(t)}). \tag{25.35}$$

未知量被限制在切空间中，这正是与欧氏 Newton 法不同的地方。方程的维数是 $\dim M$，而不是环境空间的维数。

球面 Rayleigh 商上这个方程可以显式解出。由式 (25.7)和式 (25.11)，方程写成

$$\boldsymbol{P}_{\boldsymbol{x}}(\boldsymbol{A}\boldsymbol{v}) - q\boldsymbol{v} = -(\boldsymbol{A}\boldsymbol{x} - q\boldsymbol{x}), \qquad \boldsymbol{v} \perp \boldsymbol{x}.$$

去掉投影时要补上一个沿 $\boldsymbol{x}$ 的未知倍数 λ。设 $\boldsymbol{A} - q\boldsymbol{I}$ 可逆，移项后得到

$$(\boldsymbol{A} - q\boldsymbol{I})(\boldsymbol{x} + \boldsymbol{v}) = \lambda \boldsymbol{x}, \qquad \boldsymbol{x} + \boldsymbol{v} = \lambda (\boldsymbol{A} - q\boldsymbol{I})^{-1}\boldsymbol{x}.$$

再用 $\boldsymbol{x}^{\top}\boldsymbol{v} = 0$ 确定 λ，也就是 $\boldsymbol{x}^{\top}(\boldsymbol{x} + \boldsymbol{v}) = 1$。于是

$$\boldsymbol{x} + \boldsymbol{v} = \frac{(\boldsymbol{A} - q\boldsymbol{I})^{-1}\boldsymbol{x}}{\boldsymbol{x}^{\top}(\boldsymbol{A} - q\boldsymbol{I})^{-1}\boldsymbol{x}}. \tag{25.36}$$

归一化之后分母的倍数消失，Newton 迭代成为

$$\boldsymbol{x}^{(t+1)} = \pm \frac{(\boldsymbol{A} - q^{(t)}\boldsymbol{I})^{-1}\boldsymbol{x}^{(t)}}{\left\| (\boldsymbol{A} - q^{(t)}\boldsymbol{I})^{-1}\boldsymbol{x}^{(t)} \right\|_2}, \tag{25.37}$$

符号由式 (25.36)决定。这就是经典的 Rayleigh 商迭代。一个特征值算法，原来是球面上的 Newton 法加归一化回缩。

变量

- $\boldsymbol{x}^{(t)}$：球面上的当前点；$q^{(t)}$：Rayleigh 商的取值。
- $\boldsymbol{z} = (\boldsymbol{A} - q^{(t)}\boldsymbol{I})^{-1}\boldsymbol{x}^{(t)}$：三维向量。
- $\lambda = 1/(\boldsymbol{x}^{(t)\top}\boldsymbol{z})$：标量，由切向条件确定。
- $\boldsymbol{v}^{(t)} = \lambda\boldsymbol{z} - \boldsymbol{x}^{(t)}$：Newton 步，切于 $\boldsymbol{x}^{(t)}$。

初始化　这里换一个更靠近解的起点，理由在后面解释。例中取

$$\boldsymbol{x}^{(0)} = \frac{1}{9}(8, 4, 1)^{\top}, \qquad q^{(0)} = \frac{64 + 32 + 4}{81} = \frac{100}{81}.$$

停止条件取 $\|\boldsymbol{g}^{(t)}\|_2 \le 10^{-6}$。

每轮更新

1. 计算 $\boldsymbol{z}$。例中第 0 轮

$$\boldsymbol{A} - q^{(0)}\boldsymbol{I} = \frac{1}{81}\,\mathrm{diag}(-19, 62, 224),$$

所以

$$\boldsymbol{z} = \left(-\frac{72}{19},\ \frac{18}{31},\ \frac{9}{224}\right)^{\top} \approx (-3.7895,\ 0.5806,\ 0.0402)^{\top}.$$

2. 计算 λ。例中 $\boldsymbol{x}^{(0)\top}\boldsymbol{z} \approx -3.1058$，所以 $\lambda \approx -0.3220$。

3. 由式 (25.36)得到 $\boldsymbol{x} + \boldsymbol{v}$，由 $\boldsymbol{v} = \lambda\boldsymbol{z} - \boldsymbol{x}$ 读出 Newton 步。例中

$$\boldsymbol{x}^{(0)} + \boldsymbol{v}^{(0)} \approx (1.2201, -0.1870, -0.0129)^{\top},$$
$$\boldsymbol{v}^{(0)} \approx (0.3312, -0.6314, -0.1241)^{\top}.$$

4. 回缩。例中 $\boldsymbol{x}^{(1)} \approx (0.9884, -0.1515, -0.0105)^{\top}$，$\|\boldsymbol{g}^{(1)}\|_2 \approx 0.1529$。

继续迭代得到表 25.7。第 3 轮满足停止条件，最终得到 $\boldsymbol{x}^{(3)} \approx \boldsymbol{e}_1$，只用了三次线性方程的求解。

表 25.7 从 $(8,4,1)^{\top}/9$ 出发的黎曼 Newton 法。最后一列是切空间上 $\boldsymbol{H}^{(t)}$ 的特征值。

t	$\boldsymbol{x}^{(t)}$	$q^{(t)}$	$\|\boldsymbol{g}^{(t)}\|_2$	$\boldsymbol{H}^{(t)}$ 的特征值
0	$(0.8889, 0.4444, 0.1111)$	1.2346	0.5036	$0.5645,\ 2.7318$
1	$(0.9884, -0.1515, -0.0105)$	1.0233	0.1529	$0.9538,\ 2.9764$
2	$(1.0000, 0.0037, 0.0001)$	1.0000	3.66×10^{-3}	$1.0000,\ 3.0000$
3	$(1.0000, 0.0000, 0.0000)$	1.0000	4.87×10^{-8}	$1.0000,\ 3.0000$

局部收敛 表中的梯度范数几乎是按立方在减小：$0.1529^3 \approx 3.6\times10^{-3}$，$(3.66\times10^{-3})^3 \approx 4.9\times10^{-8}$。一般情形的局部结论是平方收敛，这里的立方来自 Rayleigh 商的特殊结构。

一般结论是：设 $\boldsymbol{x}^\star$ 是驻点，$\operatorname{Hess} f(\boldsymbol{x}^\star)$ 可逆，f 足够光滑，R 是光滑回缩，则存在 $\boldsymbol{x}^\star$ 的邻域，从其中出发的迭代 (25.35)收敛到 $\boldsymbol{x}^\star$，至少是平方速度。

严格证明要把迭代写进一张局部坐标图，再逐项控制回缩与坐标化带来的误差，篇幅较长，读者可查阅专门讨论流形优化的著作[1]。机制是这样的：第 25.3.2节表明，拉回 Hessian 与黎曼 Hessian 之差正比于 $\|\operatorname{grad} f\|_2$，在解附近这个差与误差同阶，而一阶量的误差对 Newton 法只产生平方量级的后果。所以这里任何光滑回缩都行，不必是二阶回缩。

[1] N. Boumal, *An Introduction to Optimization on Smooth Manifolds*, Cambridge University Press, 2023

立方的来历可以直接算出。设 $\boldsymbol{x} = \cos e\,\boldsymbol{e}_1 + \sin e\,\boldsymbol{u}$，$\boldsymbol{u}$ 是 $\boldsymbol{A}$ 的另一单位特征向量，特征值 λ_u。Rayleigh 商的误差是二阶的：

$$q - \lambda_1 = (\lambda_u - \lambda_1)\sin^2 e.$$

$(\boldsymbol{A} - q\boldsymbol{I})^{-1}$ 把 $\boldsymbol{e}_1$ 分量放大 $1/(\lambda_1 - q)$ 倍，把 $\boldsymbol{u}$ 分量放大 $1/(\lambda_u - q)$ 倍。两个分量的比值给出新的夹角：

$$\tan e^{+} = \tan e \cdot \frac{|\lambda_1 - q|}{|\lambda_u - q|} = \tan e \cdot \frac{\sin^2 e}{\cos^2 e} = \tan^3 e.$$

这里用了 $\lambda_u - q = (\lambda_u - \lambda_1)\cos^2 e$。当 $\boldsymbol{x}$ 的误差主要在一个特征方向上时立方律是精确的，这解释了表中系数接近一。

图 25.18把这个速度与上一节的梯度下降放在同一张图上。

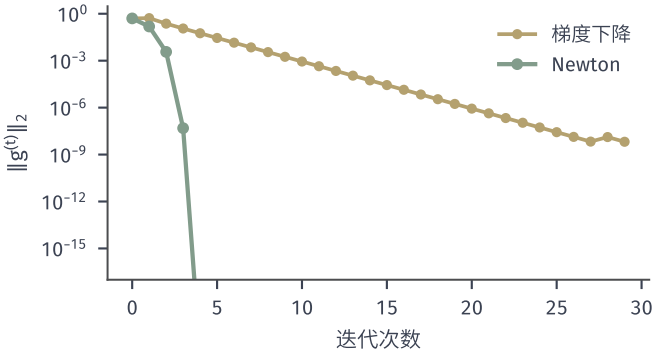


图 25.18 从同一起点 $(8,4,1)^{\mathsf{T}}/9$ 出发的黎曼梯度范数。绿线是黎曼 Newton 法，黄线是回溯线搜索的梯度下降。

远离解时 回到原来的起点 $\boldsymbol{x}^{(0)} = \frac{1}{3}(2,2,1)^{\mathsf{T}}$，就能看到为什么上面要换起点。在基 $\boldsymbol{E}_1, \boldsymbol{E}_2$ 下，$\boldsymbol{g}$ 和 $\boldsymbol{H}$ 的坐标表示可由 $\boldsymbol{A} - q\boldsymbol{I}$（对角元为 $-\frac{7}{9}, \frac{2}{9}, \frac{20}{9}$）算出：

$$\boldsymbol{g} = \begin{bmatrix} 2/9 \\ -8/9 \end{bmatrix}, \qquad \boldsymbol{H} = \begin{bmatrix} 1 & -10/9 \\ -10/9 & 2/3 \end{bmatrix}, \qquad \det \boldsymbol{H} = -\frac{46}{81}.$$

行列式为负，$\boldsymbol{H}$ 的特征值约为 -0.290 和 1.957，这里模型非退化，但不正定。

解线性方程，得到 Newton 步的坐标

$$\boldsymbol{v} = -\boldsymbol{H}^{-1}\boldsymbol{g} = -\Big(\frac{34}{23}, \frac{26}{23}\Big)^{\mathsf{T}}.$$

检查方向导数，它是正的：

$$\langle \boldsymbol{g}, \boldsymbol{v} \rangle = -\frac{2}{9} \cdot \frac{34}{23} + \frac{8}{9} \cdot \frac{26}{23} = \frac{140}{207} > 0.$$

Newton 步是上升方向。回缩后的点约为 $(-0.274, 0.960, 0.048)^{\mathsf{T}}$，目标值从 0.889 升到 0.965，这个点靠近鞍点 $\boldsymbol{e}_2$。

这个现象并非偶然。Newton 法寻找的是驻点，它对极小点、鞍点和极大点一视同仁。图 25.19标出未加保护的 Rayleigh 商迭代从球面上各点出发时的去向，起点 $\boldsymbol{x}^{(0)}$ 恰好落在通往 $\boldsymbol{e}_2$ 的区域。

25.1 流形上的优化问题
25.2 最优性与导数计算
25.3 迭代的几何运算
25.4 一阶方法
25.5 二阶方法
25.5.1 黎曼 Newton 法
25.5.2 阻尼与非精确求解
25.6 拟 Newton 法
25.7 黎曼信赖域
25.8 表示与计算成本
25.9 本章小结

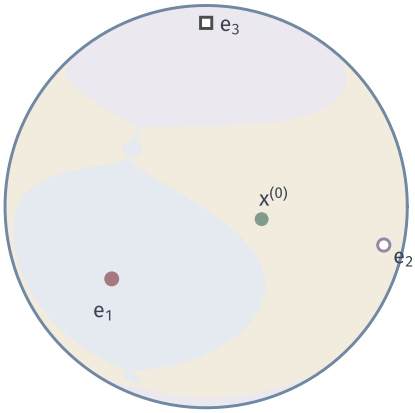


图 25.19 未加保护的黎曼 Newton 迭代的去向。每个点的底色表示从该点出发 40 步后趋向哪一对特征向量：浅蓝趋向 $\pm\boldsymbol{e}_1$，浅黄趋向 $\pm\boldsymbol{e}_2$，浅紫趋向 $\pm\boldsymbol{e}_3$。绿点是起点 $\boldsymbol{x}^{(0)}$，它落在浅黄区域。

25.5.2 阻尼与非精确求解

Newton 步需要两层保护：方向要下降，步长要合适。规模大的时候还有第三个问题，线性方程不能精确求解。这三件事的思想都来自第 7章，本节只说明在切空间上有什么变化。

修正曲率 若 $\boldsymbol{H}$ 在切空间上正定，Newton 步是下降方向，因为

$$\langle \boldsymbol{g}, \boldsymbol{v} \rangle = -\langle \boldsymbol{v}, \boldsymbol{H}[\boldsymbol{v}] \rangle < 0.$$

否则就把 $\boldsymbol{H}$ 换成 $\boldsymbol{H} + \tau \boldsymbol{I}$，$\tau > 0$ 大到足以使它在切空间上正定。这里的 $\boldsymbol{I}$ 是切空间上的恒等算子。

在贯穿例的起点取 $\tau = 1$，修正后的特征值约为 0.710 和 2.957，正定。解线性方程得到

$$\boldsymbol{v} = -(\boldsymbol{H} + \boldsymbol{I})^{-1}\boldsymbol{g} = \left(\frac{5}{17},\ \frac{62}{85}\right)^{\mathsf{T}} \approx (0.2941,\ 0.7294)^{\mathsf{T}}.$$

方向导数约为 -0.583，确实下降。用 $c_1 = \frac{1}{4}$ 做回缩线搜索，试探 $\alpha = 1$，得到

$$R_{\boldsymbol{x}^{(0)}}(\boldsymbol{v}) \approx (0.9833, 0.1788, 0.0339)^{\mathsf{T}}, \qquad f \approx 0.5177.$$

下降约 0.371，超过要求的 0.146，接受。这一步的目标值比梯度下降第 1 轮的 0.6468 小得多。

Armijo 线搜索在这里同样要针对回缩后的点。切向方向下降只保证步足够短时有效，与第 25.4.1节的道理相同。

用 Hessian–向量乘积代替形成矩阵 当 $\dim M$ 很大时，不可能写出 $\boldsymbol{H}$ 的矩阵。Rayleigh 商的式 (25.11)告诉我们，算 $\boldsymbol{H}[\boldsymbol{v}]$ 只需要一次 $\boldsymbol{A}$ 乘向量和一次投影，所以可以用线性共轭梯度法迭代求解式 (25.35)。

这里的“共轭梯度”要与第 25.4.2节区分开，表 25.8列出区别。内层 CG 全程在同一个切空间中，解一个线性方程，不需要回缩和搬运。

表 25.8 两种共轭梯度。

	内层线性 CG	黎曼共轭梯度
解决的问题	切空间内的线性方程	流形上的非线性优化
所在空间	固定的 $T_{\boldsymbol{x}}M$	每轮更换切空间
回缩与搬运	不需要	每轮都需要
曲率使用	Hessian–向量乘积	不使用

按切空间的残差设定精度 线性方程不必解得太准。切空间内的残差是 $\boldsymbol{r} = \boldsymbol{H}[\boldsymbol{v}] + \boldsymbol{g}$，内层在下述条件满足时停止：

$$\|\boldsymbol{r}\|_2 \le \eta^{(t)} \|\boldsymbol{g}^{(t)}\|_2. \tag{25.38}$$

第 7章的结论在这里同样适用：固定的 $\eta < 1$ 一般只给出线性收敛，$\eta^{(t)} \to 0$ 给出超线性收敛，$\eta^{(t)} = O(\|\boldsymbol{g}^{(t)}\|_2)$ 在解附近恢复平方收敛。

图 25.20是 $n = 500$ 的实验。三种规则的总 Hessian–向量乘积数分别约为 815、815、855，差别很小，外层迭代数分别为 60、43、41。收益集中在收尾阶段：远离解时三条曲线几乎重合，此时的工作量由全局下降决定，更严的容差也帮不上忙。

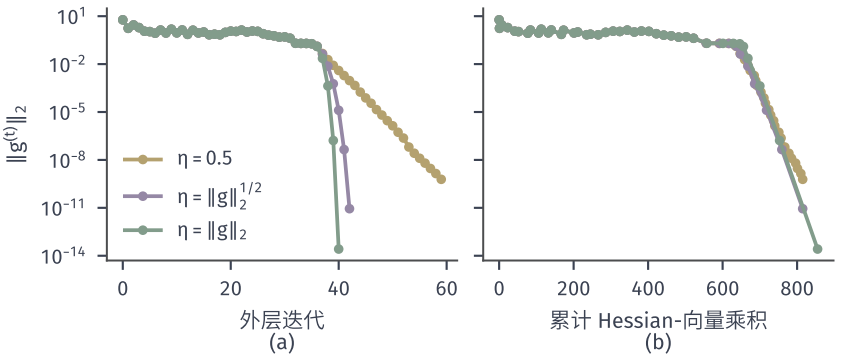


图 25.20 $n = 500$，$\boldsymbol{A}$ 的特征值在 1 到 100 之间等距，随机起点固定，球面上的 Newton–CG 加回溯线搜索。内层容差分别取 $\eta = 0.5$（黄）、$\min\{0.5, \|\boldsymbol{g}\|_2^{1/2}\}$（紫）、$\min\{0.5, \|\boldsymbol{g}\|_2\}$（绿）。(a) 按外层迭代。(b) 按累计 Hessian–向量乘积。

25.1 流形上的优化问题
25.2 最优性与导数计算
25.3 迭代的几何运算
25.4 一阶方法
25.5 二阶方法
25.6 拟 Newton 法
25.6.1 黎曼 BFGS
25.6.2 有限记忆方法
25.7 黎曼信赖域
25.8 表示与计算成本
25.9 本章小结

负曲率与切向数值误差 内层 CG 计算 $\langle \boldsymbol{d}, \boldsymbol{H}[\boldsymbol{d}]\rangle$ 时，若它不大于零，说明遇到了负曲率方向，线性方程的解不再是模型的极小点。这时要停止 CG：若是第一步，取负梯度方向；否则返回当前的 $\boldsymbol{v}$，它仍是下降方向。

另一个要小心的是舍入误差。理论上 $\boldsymbol{H}$ 把切空间映到切空间，CG 的向量始终是切向的。实际计算中会累积沿法向的分量，维数高、CG 步数多时尤其明显。常用做法是每隔若干步把 $\boldsymbol{v}$、$\boldsymbol{r}$ 和 $\boldsymbol{d}$ 重新投影到切空间。

25.6 拟 Newton 法

Hessian 难以形成或求解时，第 8章用相邻两点的梯度差逐步学习曲率。流形上的困难在于，步、梯度差和曲率近似分属不同的切空间。这就需要回答：怎样把这些量放到同一切空间中，使割线关系和正定性仍然成立？

25.6.1 黎曼 BFGS

主要思想 割线关系需要一个步和一个梯度差。把它们都放到新点 $\boldsymbol{x}^{+} = R_{\boldsymbol{x}}(\alpha \boldsymbol{d})$ 的切空间：

$$\boldsymbol{s} = \mathcal{T}_{\boldsymbol{x}\to\boldsymbol{x}^{+}}(\alpha \boldsymbol{d}), \qquad \boldsymbol{y} = \boldsymbol{g}^{+} - \mathcal{T}_{\boldsymbol{x}\to\boldsymbol{x}^{+}}(\boldsymbol{g}). \tag{25.39}$$

这样 $\boldsymbol{s}, \boldsymbol{y} \in T_{\boldsymbol{x}^{+}}M$，内积用该点的度量计算。

旧的近似算子 $\boldsymbol{B}$ 作用在 $T_{\boldsymbol{x}}M$ 上，也要搬过去。自然的办法如图 25.21所示，先搬回旧切空间，作用 $\boldsymbol{B}$，再搬到新切空间：

$$\widetilde{\boldsymbol{B}} = \mathcal{T}\, \boldsymbol{B}\, \mathcal{T}^{-1}. \tag{25.40}$$

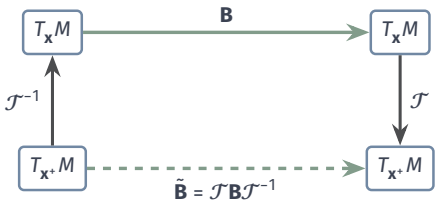


图 25.21 曲率算子的搬运。绿色实线是旧切空间上的算子，虚线是新切空间上的算子，它由另外三段复合而成：先用 $\mathcal{T}^{-1}$ 回到旧切空间，作用 $\boldsymbol{B}$，再用 $\mathcal{T}$ 搬到新切空间。

这个构造对 $\mathcal{T}$ 有要求。若 $\mathcal{T}$ 等距，则 $\widetilde{\boldsymbol{B}}$ 仍是自伴的，正定性也保留，因为

$$\langle \boldsymbol{u}, \widetilde{\boldsymbol{B}}\boldsymbol{u}\rangle = \langle \mathcal{T}^{-1}\boldsymbol{u}, \boldsymbol{B}\mathcal{T}^{-1}\boldsymbol{u}\rangle.$$

等距这一条不能省略。在标准正交坐标下取 $\mathcal{T}=\operatorname{diag}(1,\frac{1}{2})$，这是一个把第二个方向缩短的非等距映射。取对称正定的 $\boldsymbol{B}$，计算得到

$$\boldsymbol{B}=\begin{bmatrix}2&1\\1&2\end{bmatrix},\qquad \mathcal{T}\boldsymbol{B}\mathcal{T}^{-1}=\begin{bmatrix}2&2\\\frac{1}{2}&2\end{bmatrix},$$

这个矩阵已经不对称了。所以投影搬运不能照搬式 (25.40)，通常要改用等距搬运，或在搬运后作自伴化处理。

在 $T_{\boldsymbol{x}^+}M$ 上做欧氏 BFGS 公式的类比，**黎曼 BFGS**（Riemannian BFGS）的更新是

$$\boldsymbol{B}^+[\boldsymbol{u}]=\widetilde{\boldsymbol{B}}[\boldsymbol{u}]-\frac{\langle\widetilde{\boldsymbol{B}}\boldsymbol{s},\boldsymbol{u}\rangle}{\langle\boldsymbol{s},\widetilde{\boldsymbol{B}}\boldsymbol{s}\rangle}\widetilde{\boldsymbol{B}}\boldsymbol{s}+\frac{\langle\boldsymbol{y},\boldsymbol{u}\rangle}{\langle\boldsymbol{y},\boldsymbol{s}\rangle}\boldsymbol{y}. \tag{25.41}$$

代入 $\boldsymbol{u}=\boldsymbol{s}$，前两项抵消，第三项给出 $\boldsymbol{B}^+[\boldsymbol{s}]=\boldsymbol{y}$，这是新切空间内的割线关系。

记 $\boldsymbol{W}$ 为 $\boldsymbol{B}$ 的逆，$\rho=1/\langle\boldsymbol{s},\boldsymbol{y}\rangle$。在等距搬运下，用第 8章的做法可得逆形式，它能直接给出方向 $\boldsymbol{d}=-\boldsymbol{W}\boldsymbol{g}$，不必解方程：

$$\boldsymbol{W}^+[\boldsymbol{u}]=\boldsymbol{V}^*\widetilde{\boldsymbol{W}}\boldsymbol{V}[\boldsymbol{u}]+\rho\langle\boldsymbol{s},\boldsymbol{u}\rangle\boldsymbol{s},\qquad \boldsymbol{V}[\boldsymbol{u}]=\boldsymbol{u}-\rho\langle\boldsymbol{s},\boldsymbol{u}\rangle\boldsymbol{y}, \tag{25.42}$$

其中 $\boldsymbol{V}^*$ 是 $\boldsymbol{V}$ 关于度量的伴随算子：

$$\boldsymbol{V}^*[\boldsymbol{u}]=\boldsymbol{u}-\rho\langle\boldsymbol{y},\boldsymbol{u}\rangle\boldsymbol{s}.$$

曲率条件　要使 $\boldsymbol{B}^+$ 保持正定，需要 $\langle\boldsymbol{s},\boldsymbol{y}\rangle>0$。欧氏情形由 Wolfe 条件保证，流形上要重新核对。设 $\mathcal{T}$ 等距，由式 (25.39)，

$$\langle\boldsymbol{s},\boldsymbol{y}\rangle=\alpha\langle\mathcal{T}\boldsymbol{d},\boldsymbol{g}^+\rangle-\alpha\langle\boldsymbol{d},\boldsymbol{g}\rangle.$$

Wolfe 条件控制的量是沿回缩曲线的导数，记回缩曲线在新点的速度为 $\mathcal{T}^{\mathrm{D}}\boldsymbol{d}$：

$$\langle\boldsymbol{g}^+,\mathcal{T}^{\mathrm{D}}\boldsymbol{d}\rangle\geq c_2\langle\boldsymbol{g},\boldsymbol{d}\rangle.$$

这和上一式的 $\langle\mathcal{T}\boldsymbol{d},\boldsymbol{g}^+\rangle$ 是不同的量。两者若只差一个正因子 b，即

$$\mathcal{T}\boldsymbol{d}=b\,\mathcal{T}^{\mathrm{D}}\boldsymbol{d},$$

代入就有

$$\langle\boldsymbol{s},\boldsymbol{y}\rangle\geq\alpha(bc_2-1)\langle\boldsymbol{g},\boldsymbol{d}\rangle. \tag{25.43}$$

下降方向满足 $\langle\boldsymbol{g},\boldsymbol{d}\rangle<0$，所以 $bc_2<1$ 时右端为正。

球面上用平行移动沿大圆走，方向恰好与回缩曲线同向。第 25.3.3节的微分回缩长度是 $\|\boldsymbol{d}\|_2/r^2$，平行移动保持长度，所以 $b = r^2 = 1 + \alpha^2\|\boldsymbol{d}\|_2^2$。贯穿例第 0 轮 $\alpha = \frac{1}{2}$，$b = \frac{98}{81} \approx 1.21$，只要 $c_2 < 0.826$ 就满足。

不满足上述配套关系时，曲率条件没有保证，要在运行中检查：若 $\langle \boldsymbol{s}, \boldsymbol{y}\rangle$ 不够大，就跳过这一次更新，只保留搬运后的 $\widetilde{\boldsymbol{W}}$。

变量

- $\boldsymbol{x}^{(t)}$：当前点；$\boldsymbol{g}^{(t)}$：黎曼梯度，存它在切空间基下的二维坐标。
- $(\boldsymbol{E}_1^{(t)}, \boldsymbol{E}_2^{(t)})$：切空间的标准正交基，用平行移动从上一轮搬来。
- $\boldsymbol{W}^{(t)}$：逆曲率近似，2×2 对称正定矩阵。
- $\boldsymbol{s}, \boldsymbol{y}$：曲率对的二维坐标；$\rho = 1/\langle \boldsymbol{s}, \boldsymbol{y}\rangle$。

因为基是用平行移动搬过来的，向量的搬运在坐标上什么也不用做，式 (25.40)也变成矩阵不变。这是采用等距搬运的计算便利。

初始化　取 $\boldsymbol{W}^{(0)} = \boldsymbol{I}_2$，基取 $\boldsymbol{E}_1, \boldsymbol{E}_2$。例中起点是 $\boldsymbol{x}^{(0)} = \frac{1}{3}(2, 2, 1)^\top$，$\boldsymbol{g}^{(0)}$ 的坐标是 $(\frac{2}{9}, -\frac{8}{9})^\top$。

每轮更新

1. 算方向的坐标 $\boldsymbol{d}^{(t)} = -\boldsymbol{W}^{(t)}\boldsymbol{g}^{(t)}$。例中第 0 轮是 $(-\frac{2}{9}, \frac{8}{9})^\top$，与梯度下降相同。
2. 沿回缩线搜索得到 $\alpha^{(t)}$，回缩得到 $\boldsymbol{x}^{(t+1)}$。例中 $\alpha = \frac{1}{2}$，$\boldsymbol{x}^{(1)}$ 与第 25.4.1节相同。
3. 用式 (25.25)搬运基，并算新梯度的坐标。例中

$$\boldsymbol{g}^{(1)} \approx (-0.3938,\ -0.2433)^\top.$$

4. 由式 (25.39)算曲率对。平行移动下坐标不变，例中

$$\boldsymbol{s} = \frac{1}{2}\boldsymbol{d}^{(0)} \approx (-0.1111,\ 0.4444)^\top,$$
$$\boldsymbol{y} = \boldsymbol{g}^{(1)} - \boldsymbol{g}^{(0)} \approx (-0.6160,\ 0.6456)^\top.$$

5. 检查曲率。例中 $\langle \boldsymbol{s}, \boldsymbol{y}\rangle \approx 0.3554 > 0$，可以更新，$\rho \approx 2.8139$。
6. 由式 (25.42)更新 $\boldsymbol{W}$。例中

$$\boldsymbol{W}^{(1)} \approx \begin{bmatrix} 0.7274 & 0.5219 \\ 0.5219 & 1.1864 \end{bmatrix}.$$

25.1 流形上的优化问题
25.2 最优性与导数计算
25.3 迭代的几何运算
25.4 一阶方法
25.5 二阶方法
25.6 拟 Newton 法
25.6.1 黎曼 BFGS
25.6.2 有限记忆方法
25.7 黎曼信赖域
25.8 表示与计算成本
25.9 本章小结

第 1 轮方向的坐标是

$$\boldsymbol{d}^{(1)} = -\boldsymbol{W}^{(1)}\boldsymbol{g}^{(1)} \approx (0.4134,\ 0.4941)^{\mathsf{T}},$$

方向导数约为 -0.2830，下降。试探 $\alpha = 1$ 得到

$$\boldsymbol{x}^{(2)} \approx (0.9955, -0.0010, -0.0944)^{\mathsf{T}}, \qquad f \approx 0.5134, \qquad \|\boldsymbol{g}^{(2)}\|_2 \approx 0.2819.$$

下面对照 $\boldsymbol{x}^{(1)}$ 处真实的黎曼 Hessian 与 $\boldsymbol{B}^{(1)} = (\boldsymbol{W}^{(1)})^{-1}$ 的坐标：

$$\boldsymbol{H}^{(1)} \approx \begin{bmatrix} 1.47 & -1.14 \\ -1.14 & 1.65 \end{bmatrix}, \qquad \boldsymbol{B}^{(1)} \approx \begin{bmatrix} 2.01 & -0.88 \\ -0.88 & 1.23 \end{bmatrix}.$$

只做一次更新，曲率对只在 $\boldsymbol{s}$ 方向上提供信息，整个矩阵还不准确，割线方向上 $\boldsymbol{B}^{(1)}\boldsymbol{s} = \boldsymbol{y}$ 精确成立。当 $\|\boldsymbol{g}^{(t)}\|_2 \le 10^{-6}$ 时结束，最终得到 $\boldsymbol{x}^{(T)} \approx \pm\boldsymbol{e}_1$。

保证的来源 下降性来自 $\boldsymbol{W}$ 的正定性，而正定性要有三个条件同时成立：正定初值、保持自伴性和内积的搬运、每轮 $\langle \boldsymbol{s}, \boldsymbol{y}\rangle > 0$。线搜索和回缩若不满足前述配套，后者就必须靠运行中检查来维持。

局部超线性收敛的结论针对具体的算法版本。已有的分析通常假定等距搬运、Wolfe 型线搜索，以及类似式 (25.43)的配套条件；证明需要处理搬运带来的额外误差项，篇幅较长，读者可查阅黎曼拟 Newton 方法的专门文献。使用投影搬运、Armijo 线搜索的简化版本在实际中也常常有效，但这些保证不能直接移用。

25.6.2 有限记忆方法

主要思想 稠密的 $\boldsymbol{W}$ 要占 $O(n^2)$ 存储，且每轮都要搬运一个算子。第 8章的 L-BFGS 只保留最近 m 对 $(\boldsymbol{s}, \boldsymbol{y})$，用两层递推算出 $\boldsymbol{W}\boldsymbol{g}$，流形上的版本思路相同，只是这些向量要跟着当前点走。

每次迭代后，把所存的向量对都搬到新切空间。递推仍是第 8章的式子，内积换成当前点的度量。第一层从最新一对到最旧一对，初始 $\boldsymbol{q} = \boldsymbol{g}$：

$$\xi_j = \rho_j \langle \boldsymbol{s}_j, \boldsymbol{q}\rangle, \qquad \boldsymbol{q} \leftarrow \boldsymbol{q} - \xi_j \boldsymbol{y}_j. \tag{25.44}$$

中间取 $\boldsymbol{z} = \gamma\boldsymbol{q}$，尺度用最新的一对计算：

$$\gamma = \frac{\langle \boldsymbol{s}, \boldsymbol{y}\rangle}{\langle \boldsymbol{y}, \boldsymbol{y}\rangle}.$$

第二层从最旧一对到最新一对：

$$\eta_j = \rho_j \langle \boldsymbol{y}_j, \boldsymbol{z} \rangle, \qquad \boldsymbol{z} \leftarrow \boldsymbol{z} + (\xi_j - \eta_j)\boldsymbol{s}_j. \tag{25.45}$$

最后的搜索方向是 $\boldsymbol{d} = -\boldsymbol{z}$。

用 $m = 1$ 在贯穿例的第 1 轮算一遍，曲率对取上一小节的结果。第一层给出

$$\xi \approx -0.1811, \qquad \boldsymbol{q} \approx (-0.5053,\ -0.1263)^{\top}.$$

中间 $\gamma \approx 0.4463$，所以 $\boldsymbol{z} \approx (-0.2255, -0.0564)^{\top}$。第二层 $\eta \approx 0.2885$，于是

$$\boldsymbol{z} \approx (-0.1734,\ -0.2651)^{\top}, \qquad \boldsymbol{d} \approx (0.1734,\ 0.2651)^{\top}.$$

方向导数约为 -0.1328，是下降方向。它与完整 BFGS 的 $(0.4134, 0.4941)^{\top}$ 方向相近、长度不同，因为初始尺度从 $\boldsymbol{I}$ 换成了 $\gamma\boldsymbol{I}$。

历史长度与成本 增大 m 减少迭代数，但每轮要搬运和内积的向量也增多。图 25.22是 $n = 500$ 的实验，m 从 1 增加到 50，迭代数从 268 降到 141，降幅不到一半，而按每轮 $(3 + 10m)$ 次向量运算的粗略模型，总运算量却增加了约 20 倍。

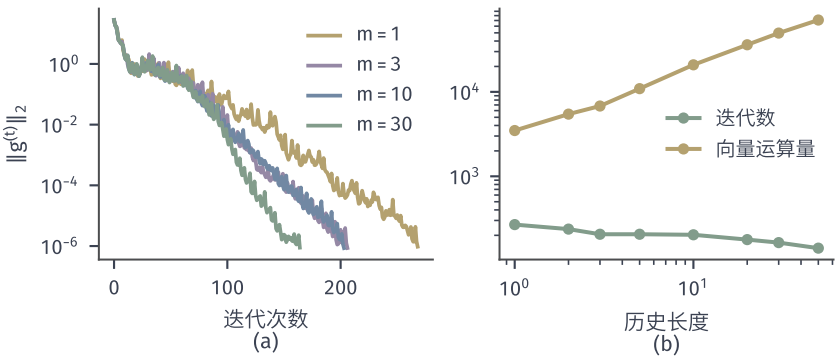


图 25.22 $n = 500$，$\boldsymbol{A}$ 的特征值在 1 到 100 之间等距，随机起点固定，使用平行移动的有限记忆黎曼 BFGS，容差 $\|\boldsymbol{g}\|_2 \le 10^{-6}$。(a) 不同历史长度 m 的梯度范数。(b) 达到容差的迭代数（绿）和按每轮 $3 + 10m$ 次向量运算估算的总运算量（黄）。

这个实验中 $\boldsymbol{A}$ 是对角阵，乘一次很便宜，搬运的代价显得突出。若 $\boldsymbol{A}$ 乘向量很昂贵，或回缩的代价高，向量运算占比就小，较大的 m 更合算。

历史信息被截断后，完整 BFGS 的局部结论不再自动成立。有限记忆方法的曲率近似只包含 m 个方向，一般只有线性收敛的保证，这与欧氏情形一致。此外，为降低成本，一些实现只在需要时才搬运向量，这也属于另一种算法版本，其性质要另行核对。

25.7 黎曼信赖域

25.1 流形上的优化问题
25.2 最优性与导数计算
25.3 迭代的几何运算
25.4 一阶方法
25.5 二阶方法
25.6 拟 Newton 法
25.7 黎曼信赖域
25.7.1 子问题的求解
25.7.2 模型与回缩条件
25.8 表示与计算成本
25.9 本章小结

第 25.5.1节的起点上，Newton 步是上升方向；第 25.3.2节的 $s=1$ 处，模型误差已经达到 $\frac{5}{18}$。这两件事都说明，曲率模型只在有限的尺度内可信。第 9章的信赖域正是处理这个问题的，本节回答它怎样搬到切空间上，又有哪些新的条件要核对。

主要思想 在当前切空间的有限半径内近似最小化模型 (25.23)：

$$\min_{\boldsymbol{v}\in T_{\boldsymbol{x}}M} \; m_{\boldsymbol{x}}(\boldsymbol{v}) \quad \text{s.t.} \quad \|\boldsymbol{v}\|_2 \le \Delta. \tag{25.46}$$

半径 Δ 在切空间里度量，子问题是线性空间上的普通信赖域子问题。

得到候选步 $\boldsymbol{v}$ 后，回缩到流形上，比较实际下降与预测下降：

$$\rho = \frac{f(\boldsymbol{x}) - f(R_{\boldsymbol{x}}(\boldsymbol{v}))}{m_{\boldsymbol{x}}(\boldsymbol{0}) - m_{\boldsymbol{x}}(\boldsymbol{v})}. \tag{25.47}$$

分子必须用回缩后的点，所以回缩造成的偏差也一并得到了检验。

接受和半径的规则沿用第 9章：$\rho \ge \frac{1}{4}$ 时接受，否则留在原地；$\rho < \frac{1}{4}$ 时半径缩小为 $\frac{1}{4}$ 倍，$\rho \ge \frac{3}{4}$ 且步到达边界时半径加倍（不超过上限 $\Delta_{\max}$），其余情形半径不变。这样曲率模型只在获得检验的尺度内被使用。这就是**黎曼信赖域**（Riemannian trust region）方法。

图 25.23画出贯穿例第 0 轮的几何。紫色椭圆是切平面上半径为 1 的圆盘，它的回缩像是球面上的绿色小圆。候选步在切平面上产生，回缩后落在绿圈之内或之上。

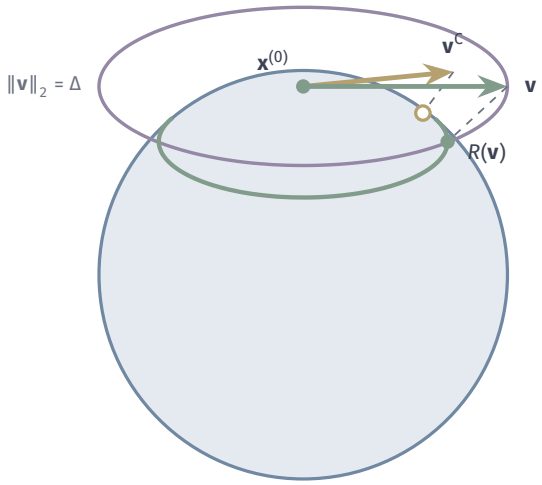


图 25.23 切平面上的信赖域及其回缩像。紫色是切平面上半径 $\Delta=1$ 的圆的边界，绿色闭曲线是它在归一化回缩下的像。黄箭头是 Cauchy 步 $\boldsymbol{v}^{\mathrm{C}}$，绿箭头是截断 CG 得到的步 $\boldsymbol{v}$，虚线是回缩，实心点是接受的新点。

25.1 流形上的优化问题
25.2 最优性与导数计算
25.3 迭代的几何运算
25.4 一阶方法
25.5 二阶方法
25.6 拟 Newton 法
25.7 黎曼信赖域
25.7.1 子问题的求解
25.7.2 模型与回缩条件
25.8 表示与计算成本
25.9 本章小结

25.7.1 子问题的求解

Cauchy 步 最便宜的办法是沿负梯度在半径内最小化模型，这就是第 9章的Cauchy 步（Cauchy step）。记沿负梯度的曲率为

$$\kappa = \frac{\langle \boldsymbol{g}, \boldsymbol{H}\boldsymbol{g}\rangle}{\|\boldsymbol{g}\|_2^2},$$

当 $\kappa > 0$ 且 $\|\boldsymbol{g}\|_2/\kappa < \Delta$ 时取 $\boldsymbol{v}^{\mathrm{C}} = -\boldsymbol{g}/\kappa$，否则走到边界。

第 9章证明了它的预测下降满足下面的下限，切空间上的证明一字不改：

$$m(\boldsymbol{0}) - m(\boldsymbol{v}^{\mathrm{C}}) \geq \frac{1}{2}\|\boldsymbol{g}\|_2 \min\Big\{\Delta,\ \frac{\|\boldsymbol{g}\|_2}{\|\boldsymbol{H}\|_2}\Big\}. \tag{25.48}$$

截断共轭梯度 只用 Cauchy 步相当于梯度法，为了利用曲率，用第 9章的**截断共轭梯度法**（truncated conjugate gradient）在切空间内迭代。迭代从 $\boldsymbol{v} = \boldsymbol{0}$ 开始，第一步就是 Cauchy 步的方向，之后模型值单调下降，所以最终的预测下降不低于 Cauchy 步。

三种情形下停止：残差足够小；遇到负曲率时沿当前方向走到边界；下一步要越界时截断在边界。残差容差取

$$\|\boldsymbol{r}\|_2 \leq \|\boldsymbol{r}_0\|_2 \min\{\|\boldsymbol{r}_0\|_2^{\theta},\ \varkappa\}, \tag{25.49}$$

其中 $\theta > 0$，$\varkappa \in (0,1)$。

变量

- $\boldsymbol{x}^{(t)}$：当前点；$\Delta^{(t)}$：半径；$\boldsymbol{g}, \boldsymbol{H}$：当前切空间基下的梯度坐标和 Hessian。
- $\boldsymbol{v}_j$：内层的当前步，$\boldsymbol{r}_j$：残差 $\boldsymbol{H}\boldsymbol{v}_j + \boldsymbol{g}$，$\boldsymbol{p}_j$：共轭方向，均为二维坐标。
- 参数：$\theta = 1$，$\varkappa = 0.1$。

初始化 例中 $\boldsymbol{x}^{(0)} = \frac{1}{3}(2,2,1)^{\mathsf{T}}$，$\Delta^{(0)} = 1$。由第 25.5.1节的数据，

$$\boldsymbol{g} = \begin{bmatrix} 2/9 \\ -8/9 \end{bmatrix}, \qquad \boldsymbol{H} = \begin{bmatrix} 1 & -10/9 \\ -10/9 & 2/3 \end{bmatrix}.$$

内层初始化为 $\boldsymbol{v}_0 = \boldsymbol{0}$，$\boldsymbol{r}_0 = \boldsymbol{g}$，$\boldsymbol{p}_0 = -\boldsymbol{g}$。

每轮更新

1. 计算 $\kappa_j = \langle \boldsymbol{p}_j, \boldsymbol{H}\boldsymbol{p}_j \rangle$。例中第 0 步 $\boldsymbol{H}\boldsymbol{p}_0 \approx (-1.2099, 0.8395)^\top$，$\kappa_0 \approx 1.0151 > 0$。

2. 若 $\kappa_j \le 0$，沿 $\boldsymbol{p}_j$ 走到边界后结束内层。否则取 $\alpha_j = \|\boldsymbol{r}_j\|_2^2 / \kappa_j$，并算 $\boldsymbol{v}_{j+1} = \boldsymbol{v}_j + \alpha_j \boldsymbol{p}_j$。例中 $\alpha_0 = \frac{153}{185} \approx 0.8270$，

$$\boldsymbol{v}_1 = \left(-\frac{34}{185}, \frac{136}{185}\right)^\top \approx (-0.1838,\ 0.7351)^\top.$$

   它的长度约为 $0.7578 < 1$，不越界，这就是 Cauchy 步，预测下降 0.3471。

3. 更新残差和方向：

$$\boldsymbol{r}_{j+1} = \boldsymbol{r}_j + \alpha_j \boldsymbol{H}\boldsymbol{p}_j, \qquad \beta_j = \frac{\|\boldsymbol{r}_{j+1}\|_2^2}{\|\boldsymbol{r}_j\|_2^2},$$

$$\boldsymbol{p}_{j+1} = -\boldsymbol{r}_{j+1} + \beta_j \boldsymbol{p}_j.$$

   例中

$$\boldsymbol{r}_1 \approx (-0.7784,\ -0.1946)^\top, \quad \beta_0 \approx 0.7668, \quad \boldsymbol{p}_1 \approx (0.6080,\ 0.8762)^\top.$$

4. 例中第 1 步 $\kappa_1 \approx -0.302 < 0$，遇到负曲率。解 $\|\boldsymbol{v}_1 + \tau \boldsymbol{p}_1\|_2 = 1$，得 $\tau \approx 0.3023$，于是

$$\boldsymbol{v} = \boldsymbol{v}_1 + \tau \boldsymbol{p}_1 = (0,\ 1)^\top.$$

   所以 $\boldsymbol{v} = \boldsymbol{E}_2$，正好是切空间的基向量，内层结束。

5. 算预测下降。例中 $m(\boldsymbol{v}) - f(\boldsymbol{x}) = -\frac{8}{9} + \frac{1}{3}$，所以预测下降 $\frac{5}{9}$。

6. 回缩并算 ρ。例中 $\boldsymbol{x}^{(0)} + \boldsymbol{E}_2 = \frac{1}{3}(4, 1, -1)^\top$，长度 $\sqrt{2}$，

$$R_{\boldsymbol{x}^{(0)}}(\boldsymbol{v}) = \frac{(4, 1, -1)^\top}{3\sqrt{2}} \approx (0.9428, 0.2357, -0.2357)^\top, \qquad f = \frac{11}{18}.$$

   实际下降 $\frac{8}{9} - \frac{11}{18} = \frac{5}{18}$，由式 (25.47)得 $\rho = \frac{1}{2}$。

7. 按规则更新。例中 $\rho = \frac{1}{2} \in [\frac{1}{4}, \frac{3}{4})$，接受这一步，半径保持 1。

对比只用 Cauchy 步：其回缩点的目标值是 0.6684，$\rho \approx 0.635$，实际下降 0.2205；截断 CG 多用一次 Hessian–向量乘积，实际下降增加到 0.2778。负曲率方向在这里提供了额外的下降，而第 25.5.1节的 Newton 方向恰恰是上升的。

图 25.24把这一轮放回切平面坐标。在原点附近模型与拉回的等值线几乎重合，到半径 1 的边界上两者已明显不同。

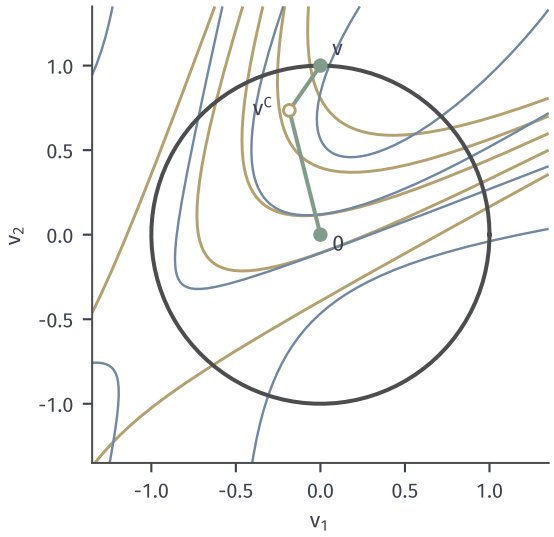


图 25.24 $\boldsymbol{x}^{(0)}$ 处切平面坐标下的模型（黄）与拉回目标（蓝）的等值线，两组曲线使用相同的水平。深灰圆是半径 $\Delta = 1$ 的边界，绿色折线是截断 CG 的路径，空心点是 Cauchy 步。模型不定，等值线不闭合。

后面几轮的结果如表 25.9。第 1 轮起都在内部收敛，ρ 迅速接近一，模型变得可信，与 Newton 法的快速局部收敛衔接。第 4 轮 $\|\boldsymbol{g}\|_2$ 约为 9.4×10^{-11}，低于容差，迭代结束，最终得到 $\boldsymbol{x}^{(4)} \approx \boldsymbol{e}_1$。

表 25.9 贯穿例的黎曼信赖域，$\Delta^{(0)} = 1$。

t	$f(\boldsymbol{x}^{(t)})$	$\|\boldsymbol{g}^{(t)}\|_2$	内层结束方式	预测下降	ρ
0	0.8889	0.9162	负曲率	0.5556	0.500
1	0.6111	0.7115	残差	0.1279	0.844
2	0.5031	0.0928	残差	3.15×10^{-3}	0.994
3	0.5000	4.68×10^{-4}	残差	1.04×10^{-7}	1.000

进展条件 实际运行中要求候选步的模型下降至少达到 Cauchy 步的某个比例，这是全局收敛分析的常用条件：存在 $c \in (0, \tfrac{1}{2}]$，使得

$$m(\mathbf{0}) - m(\boldsymbol{v}) \geq c\|\boldsymbol{g}\|_2 \min\Big\{\Delta,\ \frac{\|\boldsymbol{g}\|_2}{\beta}\Big\}, \tag{25.50}$$

这里 $\beta \geq \|\boldsymbol{H}\|_2$。截断 CG 自动满足它，取 $c = \tfrac{1}{2}$。

这个条件只针对一阶进展。更强的二阶驻点保证要求子问题求解器能处理负曲率。截断 CG 从 $\boldsymbol{v} = \mathbf{0}$ 出发，第一步方向是 $-\boldsymbol{g}$，当 $\boldsymbol{g} = \mathbf{0}$ 时立即停止。贯穿例中恰好落在鞍点 $\boldsymbol{e}_2$ 时，$\boldsymbol{g} = \mathbf{0}$，切向曲率有 -1，但截断 CG 返回零步，迭代就此停住。

25.1 流形上的优化问题
25.2 最优性与导数计算
25.3 迭代的几何运算
25.4 一阶方法
25.5 二阶方法
25.6 拟 Newton 法
25.7 黎曼信赖域
25.7.1 子问题的求解
25.7.2 模型与回缩条件
25.8 表示与计算成本
25.9 本章小结

要逃出这样的点，须在小梯度时计算 $\boldsymbol{H}$ 的最小特征值及其特征向量，并沿该方向走一步，这个步称为特征步。第 10章的讨论在切空间上同样适用。

25.7.2 模型与回缩条件

近似误差进入比值 由式 (25.47)，因为 $m(\mathbf{0}) = f(\boldsymbol{x})$，比值的偏差可以写成

$$1 - \rho = \frac{\hat{f}_{\boldsymbol{x}}(\boldsymbol{v}) - m_{\boldsymbol{x}}(\boldsymbol{v})}{m_{\boldsymbol{x}}(\mathbf{0}) - m_{\boldsymbol{x}}(\boldsymbol{v})}. \tag{25.51}$$

分子是拉回目标与模型的差，分母是预测下降，所有误差都集中在分子。分子由三部分组成：回缩对一阶和二阶信息的近似、$\boldsymbol{H}$ 与真实曲率的差、拉回函数的高阶余项。

分母受子问题求解精度的影响。子问题解得差，分母偏小，比值波动就大。所以这个比值同时检验了模型、回缩和子问题三者。

达到小梯度 下面的定理说明，什么样的近似误差足以保证梯度变小。这里假定拉回目标与模型之差被二次函数界住。

定理 25.9 黎曼信赖域的迭代界 设 f 有下界 $f^\star$，所有迭代满足式 (25.50)，$\|\boldsymbol{H}^{(t)}\|_2 \le \beta$，并且存在 $C \ge \beta$，使

$$\left|\hat{f}_{\boldsymbol{x}^{(t)}}(\boldsymbol{v}) - m_{\boldsymbol{x}^{(t)}}(\boldsymbol{v})\right| \le \frac{C}{2}\|\boldsymbol{v}\|_2^2, \qquad \|\boldsymbol{v}\|_2 \le \Delta_{\max}. \tag{25.52}$$

按本节规则更新半径。若前 T 轮都有 $\|\boldsymbol{g}^{(t)}\|_2 \ge \varepsilon$，令

$$\underline{\Delta} = \min\left\{\Delta^{(0)}, \frac{c\varepsilon}{8C}\right\}, \tag{25.53}$$

则

$$T \le \frac{6\left(f(\boldsymbol{x}^{(0)}) - f^\star\right)}{c\,\varepsilon\,\underline{\Delta}} + \frac{1}{2}\log_2 \frac{\Delta^{(0)}}{\underline{\Delta}}. \tag{25.54}$$

所以小的 ε 对应的迭代次数为 $O(1/\varepsilon^2)$。

证明 第一步证明半径小时比值接近一。设 $\|\boldsymbol{g}\|_2 \ge \varepsilon$，并设 $\Delta \le c\varepsilon/(2C)$。因为 $c \le \frac{1}{2}$，$C \ge \beta$，所以 Δ 不超过 $\|\boldsymbol{g}\|_2/\beta$，式 (25.50)给出预测下降至少为 $c\varepsilon\Delta$。

再由式 (25.51)和式 (25.52)，并用 $\|\boldsymbol{v}\|_2 \le \Delta$，得到

$$|1 - \rho| \le \frac{C\Delta^2/2}{c\varepsilon\Delta} = \frac{C\Delta}{2c\varepsilon} \le \frac{1}{4}.$$

于是 $\rho \ge \frac{3}{4}$，半径不会缩小。

第二步给出半径的下界。半径只在 $\rho < \frac{1}{4}$ 时缩小，此时一定有 $\Delta > c\varepsilon/(2C)$，缩小后仍大于 $c\varepsilon/(8C)$。因此所有轮都有 $\Delta^{(t)} \ge \underline{\Delta}$。

第三步数接受的轮数 T_{a}。接受时 $\rho \ge \frac{1}{4}$，再用预测下降的下限，并用 $\underline{\Delta} \le \varepsilon/\beta$，得到

$$f(\boldsymbol{x}^{(t)}) - f(\boldsymbol{x}^{(t+1)}) \ge \frac{1}{4} c\varepsilon \underline{\Delta}.$$

目标总下降量不超过 $f(\boldsymbol{x}^{(0)}) - f^{\star}$，所以

$$T_{\mathrm{a}} \le \frac{4\big(f(\boldsymbol{x}^{(0)}) - f^{\star}\big)}{c\varepsilon\underline{\Delta}}.$$

第四步数拒绝的轮数 T_{r}。每次拒绝半径乘 $\frac{1}{4}$，每次接受半径至多乘 2，所以

$$\underline{\Delta} \le \Delta^{(T)} \le \Delta^{(0)}\, 2^{T_{\mathrm{a}}}\, 4^{-T_{\mathrm{r}}}.$$

取对数得

$$T_{\mathrm{r}} \le \frac{1}{2} T_{\mathrm{a}} + \frac{1}{2} \log_2 \frac{\Delta^{(0)}}{\underline{\Delta}}.$$

把 $T = T_{\mathrm{a}} + T_{\mathrm{r}}$ 合起来，就得到式 (25.54)。 ■

定理的假设分三项，各起一种作用。式 (25.50)保证分母足够大；$\|\boldsymbol{H}\|_2 \le \beta$ 保证小半径时走到边界的量级被正确估计；式 (25.52)保证分子足够小。

这个假设对回缩的要求不高。把式 (25.28)类型的双侧上界与 $\|\boldsymbol{H}\|_2 \le \beta$ 相加，就得到式 (25.52)，这时 $\boldsymbol{H}$ 甚至不必是真实的 Hessian，例如用 $\boldsymbol{H} = \boldsymbol{0}$ 也行，此时算法退化为带半径控制的梯度法。在紧流形上，光滑目标和光滑回缩自动满足该假设。

二阶驻点与快速局部收敛 定理只说梯度变小。要达到近似二阶驻点，即 $\boldsymbol{H} \succeq -\varepsilon_H \boldsymbol{I}$，需要额外条件：$\boldsymbol{H}$ 在拉回 Hessian 的一定精度内，模型误差有三次界，子问题在负曲率时能产生下降正比于负曲率立方的步。在这些条件下，迭代次数的量级为 $O(\max\{\varepsilon^{-2}\varepsilon_H^{-1}, \varepsilon_H^{-3}\})$，证明沿用定理 25.9的结构并加入负曲率情形，读者可查阅[2]。

即使达到了二阶驻点，也不能断言是局部极小。第 25.2节的 x_2^3 例子满足二阶必要条件却不是局部极小。近似二阶驻点只是必要条件的数值形式。

快速局部收敛需要模型足够精确。若迭代收敛到非退化的极小点，$\boldsymbol{H}^{(t)}$ 是真实的黎曼 Hessian，并用式 (25.49)控制内层精度，那么 $\rho \to 1$，半径不再起作用，方法变成非精确 Newton，局部收敛阶至少是 $\min\{1+\theta, 2\}$。

25.1 流形上的优化问题
25.2 最优性与导数计算
25.3 迭代的几何运算
25.4 一阶方法
25.5 二阶方法
25.6 拟 Newton 法
25.7 黎曼信赖域
25.8 表示与计算成本
25.9 本章小结

证明需要回缩与 Hessian 的局部误差估计，这里只说明机制：第 25.3.2节的附加项正比于 $\|\boldsymbol{g}\|_2$，一般回缩也不破坏这一速度。

图 25.25是 $n = 300$ 的问题。半径初值 2 过大，第 0 轮 $\rho \approx 0.20$ 被拒绝，半径缩小到 0.5；第 1 轮 $\rho \approx 0.80$，半径扩大到 1，此后半径保持不变。最后几轮 $\rho \approx 1$，梯度范数快速下降。

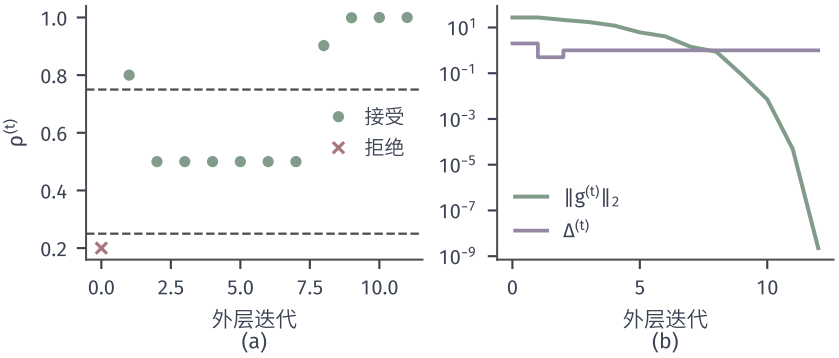


图 25.25　$n = 300$，$\boldsymbol{A}$ 的特征值在 1 到 100 之间等距，随机起点固定，$\theta = 1$，$\varkappa = 0.1$，$\Delta^{(0)} = 2$。(a) 各轮的比值 ρ，绿点接受，红叉拒绝，两条虚线是 $\frac{1}{4}$ 与 $\frac{3}{4}$。(b) 梯度范数（绿）和半径（紫）。

25.8 表示与计算成本

前面的算法都在给定的表示上运行。这一节要回答两个问题：同一对象有多种矩阵记录时应该怎样处理，流形方法与一般约束方法放在同一标准下比较时结果如何。

同一子空间的多种表示　最小化 k 个最小特征值之和可以写成

$$\min_{\boldsymbol{X}\in \mathrm{St}(k,n)} f(\boldsymbol{X}) = \frac{1}{2}\operatorname{tr}\!\left(\boldsymbol{X}^{\top}\boldsymbol{A}\boldsymbol{X}\right). \tag{25.55}$$

对任意 $k \times k$ 正交矩阵 $\boldsymbol{Q}$，$f(\boldsymbol{X}\boldsymbol{Q}) = f(\boldsymbol{X})$，因为迹对循环置换不变。所以目标只取决于 $\boldsymbol{X}$ 的列空间，而不取决于所选的基。图 25.26(a) 中三组不同的基张成同一个平面，目标值相同。

Stiefel 流形上的点与子空间的对应是多对一的。子空间全体构成 Grassmann 空间 $\mathrm{Gr}(k,n)$，它是 $\mathrm{St}(k,n)$ 对右乘正交矩阵的商，维数是 $k(n-k)$，比 Stiefel 流形少 $k(k-1)/2$。其光滑结构的建立可参考卷四第 29 章“Lie 群”。

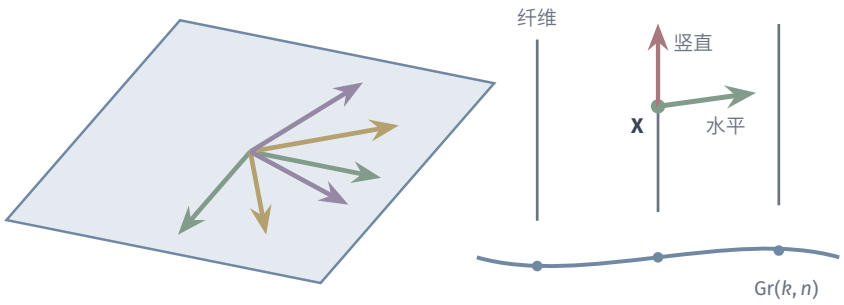


图 25.26 子空间的多种表示。(a) 同一平面（浅蓝）的三组标准正交基，绿、黄、紫三组箭头分别对应一种基。(b) 商结构的示意：底部曲线代表 $\mathrm{Gr}(k,n)$，每点上方的竖线（纤维）是表示同一子空间的所有 $\boldsymbol{X}$；红箭头是竖直方向，沿它移动子空间不变，绿箭头是水平方向。

竖直方向与水平方向 沿曲线 $\boldsymbol{X}\exp(t\boldsymbol{\Omega})$（$\boldsymbol{\Omega}$ 反对称）移动，子空间不变，它的速度 $\boldsymbol{X}\boldsymbol{\Omega}$ 称为竖直方向。与竖直方向正交的切向量满足 $\boldsymbol{X}^{\top}\boldsymbol{\Delta}=\boldsymbol{0}$，它们构成水平空间，每个水平方向都真正改变子空间。

这种分解对梯度有简单的影响。因为 f 沿竖直方向不变，$\operatorname{grad} f$ 没有竖直分量。由投影公式 (25.18)和 $\nabla\tilde{f}=\boldsymbol{A}\boldsymbol{X}$，$\boldsymbol{X}^{\top}\boldsymbol{A}\boldsymbol{X}$ 对称，于是

$$\operatorname{grad} f(\boldsymbol{X})=\boldsymbol{A}\boldsymbol{X}-\boldsymbol{X}\big(\boldsymbol{X}^{\top}\boldsymbol{A}\boldsymbol{X}\big)=(\boldsymbol{I}-\boldsymbol{X}\boldsymbol{X}^{\top})\boldsymbol{A}\boldsymbol{X}. \tag{25.56}$$

满足 $\boldsymbol{X}^{\top}\operatorname{grad} f=\boldsymbol{0}$，确实是水平的。驻点的条件是 $\boldsymbol{X}$ 的列空间是 $\boldsymbol{A}$ 的不变子空间。

用贯穿的矩阵算一次。取 $\boldsymbol{X}=[\boldsymbol{x}^{(0)},\boldsymbol{E}_1]$，先算

$$\boldsymbol{X}^{\top}\boldsymbol{A}\boldsymbol{X}=\frac{1}{9}\begin{bmatrix}16 & 2\\ 2 & 25\end{bmatrix},\qquad f(\boldsymbol{X})=\frac{41}{18}.$$

把它代入式 (25.56)，得到

$$\operatorname{grad} f(\boldsymbol{X})=\frac{1}{27}\begin{bmatrix}-16 & -20\\ 8 & 10\\ 16 & 20\end{bmatrix}.$$

两列都平行于法向量 $\boldsymbol{n}=\frac{1}{3}(-2,1,2)^{\top}$，也就是与平面 $\operatorname{span}\boldsymbol{X}$ 垂直的方向。这正好符合水平的要求：要改变一个平面，只能把基朝平面外转动。

取 $\alpha = \frac{1}{2}$，先走到 $\boldsymbol{X} - \frac{1}{2}\operatorname{grad} f(\boldsymbol{X})$，然后作回缩。QR 回缩与极分解回缩的结果分别是

$$\boldsymbol{X}^{\mathrm{QR}} \approx \begin{bmatrix} 0.8800 & 0.4504 \\ 0.4738 & -0.8549 \\ 0.0338 & 0.2574 \end{bmatrix}, \qquad \boldsymbol{X}^{\mathrm{pol}} \approx \begin{bmatrix} 0.8298 & 0.5373 \\ 0.5580 & -0.8025 \\ 0.0076 & 0.2595 \end{bmatrix}.$$

两者列空间相同，目标值都约为 1.5788，比原来的 2.2778 小。子空间问题的回缩，只有列空间才有意义，QR 分解与极分解的差别不影响目标。

冗余对曲率的影响 竖直方向对 Newton 型方法有实质影响。由第 25.2节的做法，Stiefel 上的 Hessian 是

$$\operatorname{Hess} f(\boldsymbol{X})[\boldsymbol{\Delta}] = \boldsymbol{P}_{\boldsymbol{X}}\big(\boldsymbol{A}\boldsymbol{\Delta} - \boldsymbol{\Delta}\boldsymbol{X}^{\top}\boldsymbol{A}\boldsymbol{X}\big). \tag{25.57}$$

取极小点 $\boldsymbol{X}^{\star} = [\boldsymbol{e}_1, \boldsymbol{e}_2]$，此时 $\boldsymbol{X}^{\top}\boldsymbol{A}\boldsymbol{X}$ 是 $\operatorname{diag}(1,2)$，$\mathrm{St}(2,3)$ 的切空间是 3 维的。取竖直方向 $\boldsymbol{\Delta} = \boldsymbol{X}^{\star}\boldsymbol{\Omega}$，$\boldsymbol{\Omega}$ 是 2×2 反对称矩阵，代入式 (25.57)算得 $\operatorname{Hess} f[\boldsymbol{\Delta}] = \boldsymbol{0}$，这个方向是零特征方向。

水平方向取 $\boldsymbol{\Delta} = \boldsymbol{e}_3\boldsymbol{b}^{\top}$，算得

$$\operatorname{Hess} f[\boldsymbol{\Delta}] = \boldsymbol{e}_3\,(3b_1,\ 2b_2).$$

所以 $\boldsymbol{X}^{\star}$ 处 Hessian 的特征值是 $3, 2, 0$，算子奇异，第 25.5.1节要求的非退化条件在 $\mathrm{St}(2,3)$ 上不成立，而这个零特征值完全是表示引入的。

商结构的办法是把 Newton 方程限制在水平空间 $\boldsymbol{X}^{\top}\boldsymbol{\Delta} = \boldsymbol{0}$ 内，这时算子只有 $3, 2$ 两个特征值，可逆。实际上就是在 $\mathrm{Gr}(k,n)$ 上计算，但存储仍用矩阵 $\boldsymbol{X}$。在目标对基变换不变时这样做减少了 $k(k-1)/2$ 个冗余维数。目标若不具备不变性（例如不同列带不同权重），列的次序和基都有意义，就要留在 Stiefel 流形上。

同一标准下比较 比较两类方法时，目标、精度和计量单位必须一致，并且要同时报告两个误差。一般约束方法不保证每步可行，只看目标值或只看驻点残差都会误判。下面用问题 (25.55)，取 $n = 200$，$k = 5$，$\boldsymbol{A}$ 的特征值在 1 到 100 之间等距。

三种方法都从同一个随机起点出发。黎曼梯度下降和黎曼信赖域使用 QR 回缩，后者在 Grassmann 结构上运行。第 22章的增广 Lagrange 方法用有限记忆拟 Newton 法解内层问题，迭代中不做回缩。残差统一在当前点作 QR 所得的 $\boldsymbol{Q}$ 上计算，以便不同方法使用同一标准：

$$\|(\boldsymbol{I} - \boldsymbol{Q}\boldsymbol{Q}^{\top})\boldsymbol{A}\boldsymbol{Q}\|_{\mathrm{F}}.$$

结果见图 25.27和表 25.10。计量单位是 $\boldsymbol{A}$ 乘一列向量的次数。增广 Lagrange 在迭代中途离开可行集，可行误差最大约为 1.66，随外层更新才回到机器精度，这时已经用了 10^5 量级的乘积。两种流形方法每一步都保持机器精度的可行性。

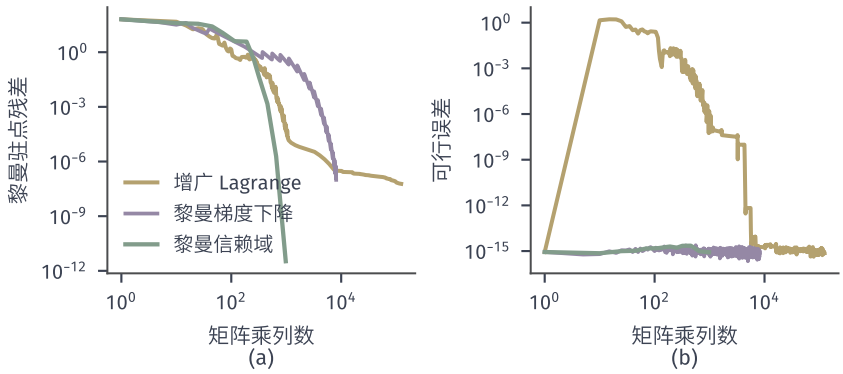


图 25.27　St(5, 200) 上的子空间问题，横轴是 $\boldsymbol{A}$ 乘列向量的累计次数。黄线为增广 Lagrange 方法，紫线为黎曼梯度下降，绿线为黎曼信赖域。(a) 黎曼驻点残差。(b) 可行误差 $\|\boldsymbol{X}^{\mathsf{T}}\boldsymbol{X}-\boldsymbol{I}\|_{\mathrm{F}}$。这是单个问题实例的一次运行，三种方法都未作专门调参。

表 25.10　图 25.27的运行结果，三种方法的黎曼驻点残差的容差均为 10^{-7}。

方法	乘列数	QR 次数	驻点残差	最大可行误差
增广 Lagrange	123560	0	5.9×10^{-8}	1.66
黎曼梯度下降	8110	3244	9.9×10^{-8}	2.4×10^{-15}
黎曼信赖域	980	11	3.4×10^{-12}	2.3×10^{-15}

计量也要诚实。这个问题的 $\boldsymbol{A}$ 是对角阵，乘一列只要 200 次运算，一次 $n\times k$ 矩阵的 QR 约需 $nk^2=5000$ 次。按此换算，黎曼梯度下降的主要代价其实是回缩：回溯的每次试探都做一次 QR，3244 次 QR 约 1.6×10^7 次运算，比矩阵乘积的 1.6×10^6 次多一个数量级。若 $\boldsymbol{A}$ 的乘积昂贵，结论又会不同。

表 25.11按运算种类汇总。流形方法的优势依赖一个前提：回缩、投影和搬运有便宜的闭式。这对球面和正交矩阵成立，对一般的非线性等式约束不成立，回缩本身可能要解一个非线性方程，这时第 21章的恢复步或第 23章的 SQP 未必更差。可行集带不等式或棱角时，本章方法也不适用。

25.1 流形上的优化问题
25.2 最优性与导数计算
25.3 迭代的几何运算
25.4 一阶方法
25.5 二阶方法
25.6 拟 Newton 法
25.7 黎曼信赖域
25.8 表示与计算成本
25.9 本章小结

表 25.11 一般约束方法与流形方法的每轮运算对比，$\mathrm{St}(k,n)$ 上的问题。

项目	一般约束方法	流形方法
导数	$\nabla \bar{f}$，约束 Jacobian	$\nabla \bar{f}$，再作投影 $O(nk^2)$
线性求解	KKT 系统，维数 $nk + k(k+1)/2$	切空间内，维数 $\dim M$
保持可行	外层逐步逼近，或恢复步	回缩，$O(nk^2)$
比较历史	同一空间，直接相减	需要搬运

报告什么 无论采用哪种方法，收尾时都要给出同样的两项：可行误差 $\|h(\boldsymbol{x})\|$ 与黎曼驻点残差 $\|\mathrm{grad}\, f(\boldsymbol{x})\|$。流形方法的可行误差应当是机器精度量级，若它随迭代缓慢增长，说明回缩或投影累积了舍入误差，需要定期重新正交化。

25.9 本章小结

本章从一个问题出发：可行集是球面或正交矩阵集合时，能否把它本身当作计算空间。答案是肯定的，但要付出代价：约束从问题的表述中消失，转而进入每一步的几何运算。所求解的仍然是约束极值，黎曼梯度为零就是 Lagrange 乘子驻定条件，切向曲率就是 Lagrange 函数的 Hessian 在切空间上的二次型。

前提是可行集具有光滑结构，这由正则等式约束保证。集合、度量和表示是三种不同的选择。集合决定极小点，度量决定梯度和曲率的尺度，表示决定成本。十字形交点、棱角这样的点上没有线性切空间，本章的迭代不能直接使用。

全部方法共用同一个循环：在切空间中产生候选步，回缩到流形，用拉回目标检验，再搬运历史向量。回缩只需要零步不动和一阶一致性，不必是测地线，也不必是最近点；二阶回缩使拉回 Hessian 等于黎曼 Hessian，一般回缩只在驻点处相等。向量搬运只保证落入新切空间并保持线性，内积和长度的保持要逐个核对。

表 25.12用贯穿例对比各种方法需要的信息及其结果，保证的来源各不相同。梯度下降的残差界依赖拉回的光滑性；共轭梯度和拟 Newton 方法还依赖线搜索、搬运与回缩的配套；Newton 法在非退化解附近快速收敛，但它寻找驻点，远离解时可能上升；信赖域用比值检验曲率模型，需要处理负曲率才能得到二阶保证。

表 25.12　本章各方法的比较。

方法	循环外还需要	贯穿例或实验中的表现
梯度下降	线搜索	每轮误差约减半
共轭梯度	搬运、重启	低维无优势，高维更快
Newton 法	Hessian 作用	近解立方，远离时可能上升
BFGS	等距搬运、曲率检查	逐步学习曲率
信赖域	半径、比值检验	利用负曲率，四轮收敛

算法的保证由度量、模型、搬运和误差控制共同决定，欧氏结论不能不加核对地移用。同一个子空间有多种矩阵记录时，商结构去掉冗余的竖直方向，使非退化条件恢复。与一般约束方法比较时，要以同一目标和精度同时报告可行误差与黎曼驻点残差，并把投影、回缩和搬运的代价计算在内。

本章的度量都是诱导度量。概率分布族上的 Fisher 度量给出另一种几何，对应的自然梯度方向的统计含义可参考卷七第 12 章“概率分布的优化与逼近”，那里需要核验信息矩阵的可逆性、步长和分布族的边界等条件。

第七部分

多目标与嵌套优化

Multiple Criteria and Nested Optimization

阅读指引

前面的问题都只有一个目标、一组变量。本部分放宽这一点，研究三种不同的结构，它们不是同一问题的三个算法变种。

第 26章处理目标是向量的情形：多个目标不能同时最优时，输出应是一组互不支配的候选方案，并讨论怎样找到并覆盖它们。第 27章研究外层最小化、内层取最坏情形的问题，两层追求相反的方向但共用一个代价。第 28章研究外层目标依赖内层最优解的问题，两层目标各不相同，关键是内层的解怎样随外层变量变化。

第 26 章

多目标优化

26.1 多目标问题
26.1.1 支配关系
26.1.2 Pareto 最优
26.1.3 目标尺度
26.2 标量化
26.3 最优解的判别
26.4 多梯度下降
26.5 前沿的计算
26.6 前沿的评价
26.7 本章小结

一个方案要同时看成本和误差。方案甲花 1 万元，误差是 8 个百分点；方案乙花 6 万元，误差是 1 个百分点。甲便宜，乙准确，两个数字都要小，却没有哪一个同时更小。前面各章的比较都落在一条数轴上，这里的比较落在一个平面上，“谁更好”这个问题第一次没有现成的答案。

常见的做法是把两个目标加起来再求解。这样做当然能得到一个数，但成本和误差的单位不同，加法里藏着一个没有说出口的汇率。换一个单位，或者换一个汇率，答案就可能换成另一个方案。所以本章要问的是：在没有汇率之前，哪些比较是站得住的？有了某种偏好之后，怎样把它写成单目标问题？需要给决策者看一整组候选的时候，怎样把这组候选算出来，又怎样判断它算得好不好？

本章先建立不依赖偏好的比较关系，得到一组互不支配的方案。然后讨论三种写出偏好的办法，比较它们各能到达哪些方案。接着转到局部信息，研究什么时候还存在让所有目标一起下降的小步，并由此构造一个不预设偏好的迭代。最后讨论怎样组织多次求解或一个种群来近似整条前沿，以及未知真实前沿时能够报告哪些量。

全章反复使用几个小例子：六个有限候选、两个二次函数，以及两条非凸的前沿。每种方法都放到这几个例子上算一遍，看它到得了哪里、到不了哪里。

26.1 多目标问题

目标从一个数变成一组数之后，“更好”和“最优”还能怎样定义？本节先把问题写出来，再找出不需要任何偏好就能成立的比较，最后说明目标的单位会影响哪些判断。

问题的形式 在同一个可行集上，同时要求 m 个目标都尽量小，这样的问题称为**多目标优化**（multi-objective optimization）：

$$\min_{\boldsymbol{x}\in\boldsymbol{C}} \ \boldsymbol{f}(\boldsymbol{x}) = \big(f_1(\boldsymbol{x}), \dots, f_m(\boldsymbol{x})\big). \tag{26.1}$$

本章的 m 始终表示目标个数。需要写约束函数时，第 26.3.2节会另外安排下标。这里的“min”暂时只是一个愿望，它的含义正是本节要确定的。

问题涉及两个空间。变量 $\boldsymbol{x}$ 所在的 $\mathbb{R}^n$ 称为**决策空间**（decision space），目标向量所在的 $\mathbb{R}^m$ 称为**目标空间**（objective space）。可行集在 $\boldsymbol{f}$ 下的像

$$\boldsymbol{Y} = \boldsymbol{f}(\boldsymbol{C}) = \{\boldsymbol{f}(\boldsymbol{x}) : \boldsymbol{x} \in \boldsymbol{C}\} \tag{26.2}$$

是所有能够实现的目标向量，称为**可达目标集**（attainable objective set）。决定方案好坏的比较发生在 $\boldsymbol{Y}$ 里，而真正要交出去的方案在 $\boldsymbol{C}$ 里。

两个贯穿全章的例子　第一个例子是有限个候选。六个方案的成本 f_1（万元）和误差 f_2（百分点）如下，数据是教学用的假设：

$$\begin{aligned} A &= (1, 8), \quad B = (2, 5), \quad C = (4, 4), \\ D &= (6, 1), \quad E = (5, 6), \quad F = (7, 1). \end{aligned} \tag{26.3}$$

这里决策空间就是六个方案的名字，目标空间是平面，$\boldsymbol{Y}$ 由六个点组成。

第二个例子是连续的。取 $\boldsymbol{C} = \mathbb{R}^2$，两个目标分别希望靠近两个不同的点：

$$f_1(\boldsymbol{x}) = \frac{1}{2}\|\boldsymbol{x} - \boldsymbol{a}\|_2^2, \qquad f_2(\boldsymbol{x}) = \frac{1}{2}\|\boldsymbol{x} - \boldsymbol{b}\|_2^2, \tag{26.4}$$

其中 $\boldsymbol{a} = (1, 0)$，$\boldsymbol{b} = (0, 1)$。想象两个仓库分别在 $\boldsymbol{a}$ 和 $\boldsymbol{b}$，要选一个地点，离两个仓库都要近。

图 26.1把这个映射画了出来。左边是决策平面，右边是目标平面，浅蓝色区域是 $\boldsymbol{Y}$。点 $\boldsymbol{p} = (1, 1)$ 与 $\boldsymbol{p}' = (0, 0)$ 关于直线 $x_1 + x_2 = 1$ 对称，到两个仓库的距离分别相同，所以落到目标平面上的同一点 $(1/2, 1/2)$。一个目标向量可以对应多个方案，这正是不能只在目标空间里回答“选哪个方案”的原因。

26.1 多目标问题
26.1.1 支配关系
26.1.2 Pareto 最优
26.1.3 目标尺度
26.2 标量化
26.3 最优解的判别
26.4 多梯度下降
26.5 前沿的计算
26.6 前沿的评价
26.7 本章小结

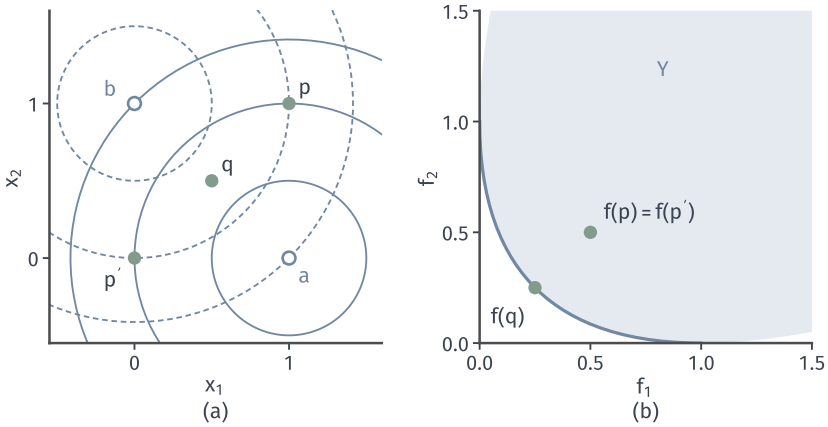


图 26.1 式 (26.4)的决策空间与目标空间。(a) 实线圆是 f_1 的等高线，虚线圆是 f_2 的等高线，绿点是三个方案。(b) 浅蓝区域是可达目标集 $\boldsymbol{Y}$，蓝线是它的左下边界。$\boldsymbol{p}$ 与 $\boldsymbol{p}'$ 对称，映到同一个目标向量；$\boldsymbol{q}=(1/2,1/2)$ 的目标向量是 $(1/4,1/4)$，两个分量都更小。

为什么没有唯一的最小 单目标问题中，任意两个实数都能比较大小，所以最小值的定义不会有歧义。向量没有这样的全序。$A=(1,8)$ 与 $D=(6,1)$ 相比，成本是 A 小，误差是 D 小。两个分量的优劣方向相反，要断定谁更好，必须先说清一万元相当于多少个百分点的误差，而题目没有给出这个信息。

因此不能指望从式 (26.1)直接得到一个点。接下来只保留不需要换算就能下的判断。

26.1.1 支配关系

不引入任何偏好，还能确定哪些比较？回到式 (26.3)，$B=(2,5)$ 与 $E=(5,6)$ 相比，B 更便宜，误差也更小。无论决策者多看重成本或多看重误差，只要两项都是越小越好，就没有理由选 E。把这种“全面不差”写成定义。

定义 26.1 支配 设 $\boldsymbol{u},\boldsymbol{v}\in\boldsymbol{C}$。若

$$f_i(\boldsymbol{u})\le f_i(\boldsymbol{v})\quad\text{对所有 } i=1,\dots,m, \tag{26.5}$$

并且至少有一个 i 使 $f_i(\boldsymbol{u})<f_i(\boldsymbol{v})$，就说 $\boldsymbol{u}$**支配**（dominate）$\boldsymbol{v}$。

式 (26.5)说的是“每一项都不差”，后半句说的是“至少有一项确实更好”。后半句不能省：没有它，两个目标向量相同的方案就会互相支配，而它们之间其实没有优劣。

26.1 多目标问题
26.1.1 支配关系
26.1.2 Pareto 最优
26.1.3 目标尺度
26.2 标量化
26.3 最优解的判别
26.4 多梯度下降
26.5 前沿的计算
26.6 前沿的评价
26.7 本章小结

用左下区域检查 在目标平面上，支配关系可以一眼看出。以一点 $\boldsymbol{y}$ 为角画出它的左下方区域和右上方区域，落在左下方的点支配 $\boldsymbol{y}$，落在右上方的点被 $\boldsymbol{y}$ 支配。图 26.2(a) 以 B 为例，平面被两条虚线分成四块。左上和右下两块中的点一个分量比 B 小，另一个分量比 B 大，这两块就是**不可比**的区域。

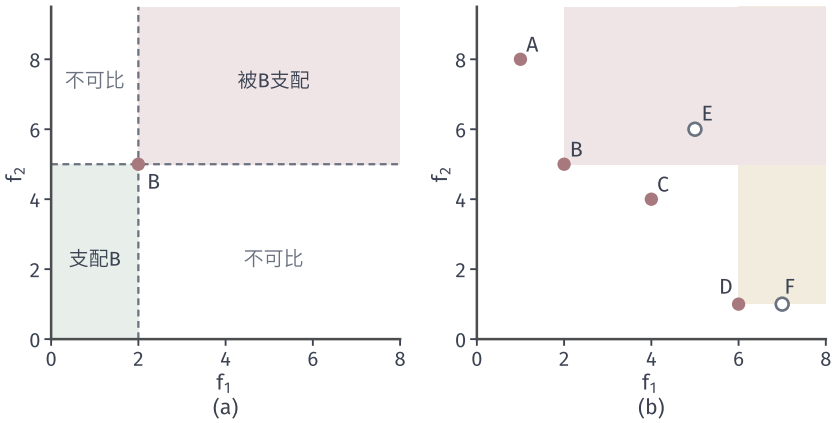


图 26.2 目标平面上的支配关系，数据为式 (26.3)。(a) 以 B 为角分出的四块区域。(b) 红点是不被任何候选支配的方案，空心点是被支配的方案。粉色是被 B 支配的区域，E 在其中；浅黄是被 D 支配的区域，F 在它的下边界上。

下面逐对检查图 26.2(b) 中的六个点。$E=(5,6)$ 被 B 支配，也被 $C=(4,4)$ 支配。$F=(7,1)$ 与 $D=(6,1)$ 误差相同，D 更便宜，所以 D 支配 F。其余的 A,B,C,D 按成本从小到大排，误差依次是 $8,5,4,1$，严格下降，任何两个都是一项更好、一项更差，互不支配。

支配是一种偏序：一个点不支配自己，支配关系可以传递，但并非任何两点都可比。可比的部分是确定的判断，不可比的部分要等偏好来决定。

26.1.2 Pareto 最优

既然只有部分方案之间能比较，“最优”就只能退一步定义：没有被其他方案全面超过。这一小节给出这个定义及其两种变形，并把它们落到两个例子上。

定义 26.2 Pareto 最优 设 $\bar{\boldsymbol{x}}\in\boldsymbol{C}$。

1. 若不存在 $\boldsymbol{x}\in\boldsymbol{C}$ 支配 $\bar{\boldsymbol{x}}$，称 $\bar{\boldsymbol{x}}$ 为Pareto 最优（Pareto optimal）点。
2. 若不存在 $\boldsymbol{x}\in\boldsymbol{C}$ 使 $f_i(\boldsymbol{x})<f_i(\bar{\boldsymbol{x}})$ 对所有 i 成立，称 $\bar{\boldsymbol{x}}$ 为弱 Pareto 最优（weakly Pareto optimal）点。

3. 若存在 $r>0$，使上述条件在 $\boldsymbol{C}$ 与 $\bar{\boldsymbol{x}}$ 的 r 邻域的交集上成立，相应地称为**局部 Pareto 最优**（locally Pareto optimal）点或局部弱 Pareto 最优点。

全体 Pareto 最优点组成的集合称为**Pareto 解集**（Pareto set），记为 $\boldsymbol{X}_{\mathrm{P}}$；它在 $\boldsymbol{f}$ 下的像 $\boldsymbol{Y}_{\mathrm{P}}=\boldsymbol{f}(\boldsymbol{X}_{\mathrm{P}})$ 称为**Pareto 前沿**（Pareto front）。

解集在决策空间，前沿在目标空间，二者不是同一个东西。多个方案可以对应前沿上的同一点，所以由前沿反推方案时还要保留决策变量。

未加“局部”二字的 Pareto 最优指全局版本，比较对象是全部可行点。全局 Pareto 最优点必定是局部 Pareto 最优点，因为比较的范围缩小了。Pareto 最优点必定是弱 Pareto 最优点，因为所有分量都严格更小的点一定支配它。

有限例 在式 (26.3)中，A,B,C,D 都不被支配，都是 Pareto 最优点。E 被 B 支配，且 B 的两个分量都严格小于 E，所以 E 连弱 Pareto 最优点也不是。

$F=(7,1)$ 被 D 支配，因此不是 Pareto 最优点。可是要两个分量都严格小于 F，误差必须小于 1，而六个方案中没有这样的。所以 F 是弱 Pareto 最优点。弱 Pareto 最优这个说法宽松，正是因为它放过了“一项持平、另一项更差”的方案。

弱 Pareto 点在目标平面上的样子 图 26.3中可达集合的边界有三段。红色曲线段上的点都是 Pareto 最优的。左侧的竖直边上，$\boldsymbol{y}$ 的左下方开象限（绿色）里没有可达点，所以 $\boldsymbol{y}$ 是弱 Pareto 最优的；但沿着竖直边往下走到 $\boldsymbol{y}'$，成本不变而误差变小，$\boldsymbol{y}'$ 支配 $\boldsymbol{y}$。底部的水平边同理，$\boldsymbol{z}'$ 支配 $\boldsymbol{z}$。

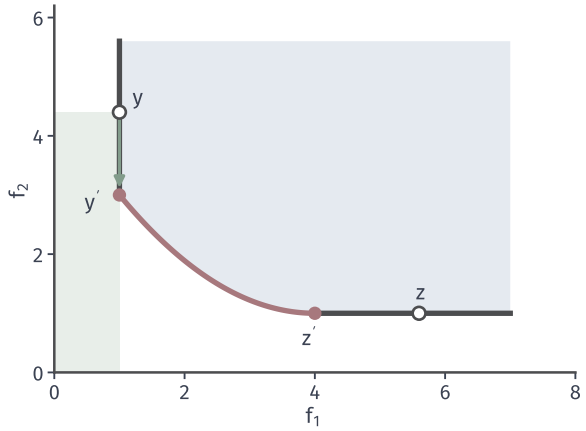


图 26.3 弱 Pareto 最优点的位置。浅蓝区域是可达目标集，红色曲线是 Pareto 前沿，深灰粗线是只有弱 Pareto 性质的竖直边和水平边。绿色是 $\boldsymbol{y}$ 的左下方开象限，其中没有可达点。绿色箭头指向支配 $\boldsymbol{y}$ 的点 $\boldsymbol{y}'$。

连续例：解集是一条线段　现在求式 (26.4)的 Pareto 解集。选坐标把几何关系拆开：把点写成沿 $\boldsymbol{a}\to\boldsymbol{b}$ 的位置 s 与到连线的带符号距离 r，

$$\boldsymbol{x}=\boldsymbol{a}+s(\boldsymbol{b}-\boldsymbol{a})+r\boldsymbol{e},\qquad \boldsymbol{e}=\frac{1}{\sqrt{2}}(1,1).$$

由于 $\boldsymbol{e}$ 是与 $\boldsymbol{b}-\boldsymbol{a}$ 垂直的单位向量，且 $\|\boldsymbol{b}-\boldsymbol{a}\|_2^2=2$，由勾股定理得到

$$f_1=s^2+\tfrac{1}{2}r^2,\qquad f_2=(1-s)^2+\tfrac{1}{2}r^2. \tag{26.6}$$

式 (26.6)说明，三种情形下都能找到严格更好的点。若 $r\neq 0$，把 r 改为 0，两个目标都严格减小。若 $r=0$ 而 $s<0$，把 s 改为 0，f_1 从 s^2 减为 0，f_2 从 $(1-s)^2$ 减为 1，两项都严格减小。$s>1$ 时对称。

所以 Pareto 最优点只可能在线段 $s\in[0,1]$，$r=0$ 上。还要确认线段上的点确实不被支配。设 $\boldsymbol{y}$ 支配线段上参数为 s 的点，按上面的做法把 $\boldsymbol{y}$ 拉回线段得到参数 s'，目标不增，于是 $\boldsymbol{f}$ 在 s' 处的值逐项不大于在 s 处的值。

线段上 $f_1=s^2$ 严格递增，$f_2=(1-s)^2$ 严格递减，两项同时不大于只能发生在 $s'=s$。这样拉回前后目标向量相等，$\boldsymbol{y}$ 与原点目标相同，与“支配”矛盾。于是

$$\boldsymbol{X}_{\mathrm{P}}=\{(1-s,s):0\le s\le 1\},\qquad \boldsymbol{Y}_{\mathrm{P}}=\{(s^2,(1-s)^2):0\le s\le 1\}. \tag{26.7}$$

图 26.4画出这一结果。线段外的点 $\boldsymbol{p}=(1,1)$ 对应目标向量 $(1/2,1/2)$，沿箭头移到 $\boldsymbol{q}$ 后目标变成 $(1/4,1/4)$，两项都减半。线段内部沿着线段移动，则是拿 f_1 换 f_2，这种交换就是**取舍**（trade-off）的含义。

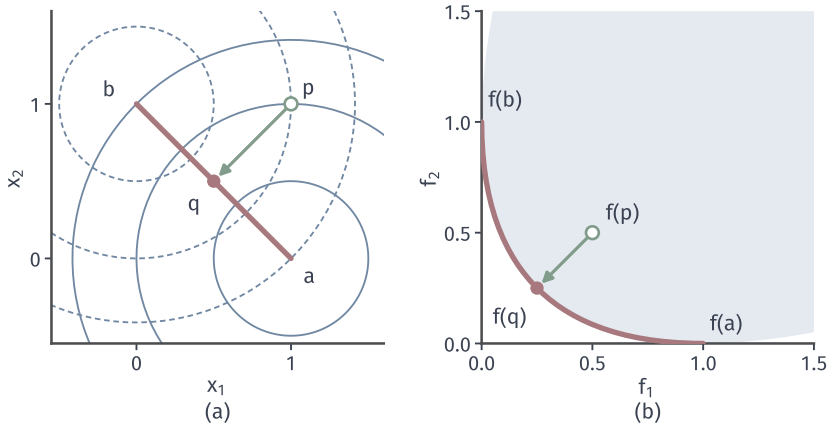


图 26.4　式 (26.4)的 Pareto 解集与 Pareto 前沿。(a) 决策平面上红色线段是解集，绿色箭头把线段外的点 $\boldsymbol{p}$ 移到 $\boldsymbol{q}$。(b) 目标平面上浅蓝区域是可达目标集，红色曲线是前沿 $(s^2,(1-s)^2)$；同一步移动使 $\boldsymbol{f}(\boldsymbol{p})$ 沿箭头落到前沿上的 $\boldsymbol{f}(\boldsymbol{q})$。

26.1 多目标问题
26.1.1 支配关系
26.1.2 Pareto 最优
26.1.3 目标尺度
26.2 标量化
26.3 最优解的判别
26.4 多梯度下降
26.5 前沿的计算
26.6 前沿的评价
26.7 本章小结

局部版本与存在性 局部 Pareto 最优只和附近的方案比。取一个变量 $x \in [0,4]$，令

$$f_1(x) = x, \qquad f_2(x) = (x-1)^2(x-3)^2 + 0.4x. \tag{26.8}$$

由于 f_1 随 x 增大，x 越大的方案越贵，所以一个方案不被支配，要求所有更便宜的方案的误差都更大。

图 26.5是这条曲线。f_2 的第一个极小点约在 $x \approx 0.953$，记对应点为 $\boldsymbol{P}$，$[0, 0.953]$ 上的 f_2 严格下降，这一段是全局 Pareto 最优的（红色）。第二个极小点约在 $x \approx 2.946$，记对应点为 $\boldsymbol{Q}$，通往 $\boldsymbol{Q}$ 的紫色下降段上，近处更便宜的方案误差更大，近处更贵的方案误差更小，互不支配，所以这一段局部 Pareto 最优。

但 $\boldsymbol{Q}$ 的两个分量约为 $(2.946, 1.189)$，$\boldsymbol{P}$ 的两个分量约为 $(0.953, 0.390)$，都更小，$\boldsymbol{P}$ 支配 $\boldsymbol{Q}$。这和单目标问题中局部最小点与全局最小点的差别是一回事，只是这里比较的是向量。

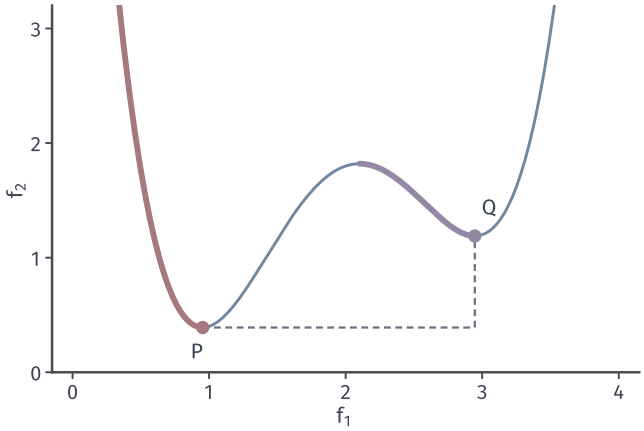


图 26.5 式 (26.8)在目标平面上的曲线。红色段全局 Pareto 最优，紫色段只局部 Pareto 最优，蓝色段的点在近处已被支配。虚线标出 $\boldsymbol{P}$ 支配 $\boldsymbol{Q}$ 的两个分量差。

Pareto 最优点也不是总存在的。取 $\boldsymbol{C} = (0, 1]$，$f_1(x) = f_2(x) = x$，任意 x 都被 $x/2$ 支配，解集是空集。这和单目标问题中最小点不存在是同一种情形，第 26.2节会给出一个保证存在的条件。

26.1.3 目标尺度

单位是人为选定的。把成本从万元换成千元，数字扩大十倍，这时哪些结论不变，哪些结论会变？

支配关系不受影响 若把每个目标换成 $\varphi_i(f_i)$，其中 φ_i 严格递增，那么 $f_i(\boldsymbol{u}) \le f_i(\boldsymbol{v})$ 与 $\varphi_i(f_i(\boldsymbol{u})) \le \varphi_i(f_i(\boldsymbol{v}))$ 等价，严格不等号也一样。所以支配

关系、Pareto 解集、弱 Pareto 解集都不变。换单位是 $\varphi_i(y) = cy$，$c > 0$，自然在其中。

固定权重的加权目标会变　把两个目标按固定权重相加，比如权重取 $(0.6, 0.4)$，得到一个分数，分数最低的方案胜出。以万元为单位，四个 Pareto 方案的分数是

$$A:\ 3.8, \qquad B:\ 3.2, \qquad C:\ 4, \qquad D:\ 4,$$

所以选 B。把成本改用千元表示，f_1 乘以 10，权重不变，分数变成

$$A:\ 9.2, \qquad B:\ 14, \qquad C:\ 25.6, \qquad D:\ 36.4,$$

这回选 A。方案本身什么也没变，变的只是记账单位，见图 26.6。

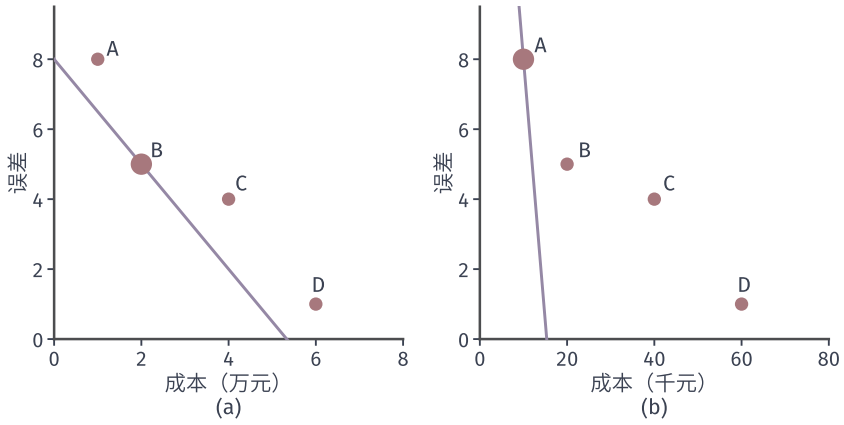


图 26.6　换单位改变加权和的选择，权重固定为 $(0.6, 0.4)$。紫线是经过分数最低方案的等分数线，大圆点是被选中的方案。(a) 成本以万元计，选中 B。(b) 成本以千元计，选中 A。四个点的相对位置在两图中按横轴比例对应，支配关系没有变化。

基于距离的比较也会变　另一种常见做法是计算到**理想点**（ideal point）的距离。理想点的每个分量是该目标单独能达到的最小值，这里是 $(1, 1)$。以万元为单位，四个方案到理想点的欧氏距离约为

$$A:\ 7, \qquad B:\ 4.12, \qquad C:\ 4.24, \qquad D:\ 5,$$

B 最近。改用千元后，理想点变为 $(10, 1)$，距离约为

$$A:\ 7, \qquad B:\ 10.77, \qquad C:\ 30.15, \qquad D:\ 50,$$

A 最近。距离把两个分量的差放在一起平方，单位大的分量就占了主导。

归一化及其参考范围 为消除单位，常把每个目标按某个参考范围线性缩放到 $[0,1]$。取目标 i 的下参考值 l_i 和上参考值 u_i，$u_i > l_i$，令

$$\tilde{f}_i = \frac{f_i - l_i}{u_i - l_i}. \tag{26.9}$$

下参考值常取理想点。上参考值常取 Pareto 方案中各目标的最大值，这样的点称为**最差点**（nadir point）。

以 A,B,C,D 的范围 $l=(1,1)$，$u=(6,8)$ 归一化，四点变成

$$A:\ (0,1),\quad B:\ (0.2,0.571),\quad C:\ (0.6,0.429),\quad D:\ (1,0).$$

到原点的距离依次约为 1，0.605，0.737，1，选 B。这一结果不再受万元或千元的影响，因为式 (26.9)的分子分母同时乘以同一个数。

但参考范围本身仍然影响结论。设候选集里多了一个 $G=(1.5,36)$，它被 A 支配，本该无关紧要。若范围取全部候选的最大值，误差的上参考值变成 36，四点的归一化误差都缩小，距离依次约为 0.2，0.230，0.606，1，选中的方案从 B 变成 A，见图 26.7。

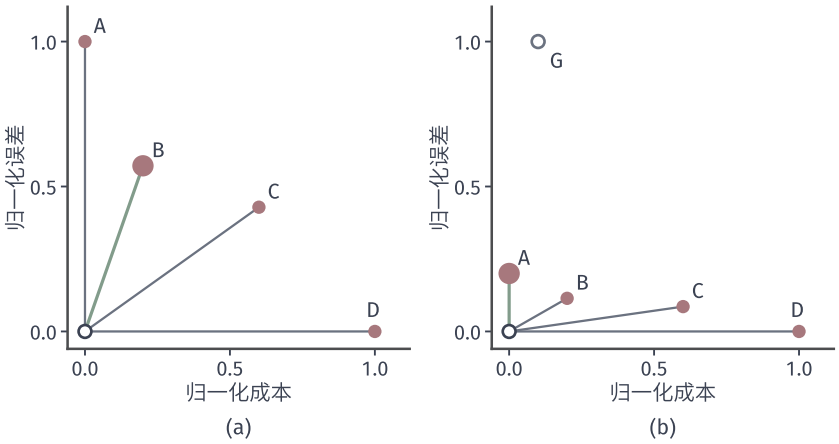


图 26.7 参考范围对归一化比较的影响。线段是各方案到理想点（原点）的距离，绿色线段是最短的一条，大圆点是被选中的方案。(a) 以 A,B,C,D 的范围归一化，选 B。(b) 候选中混入被支配的 $G=(1.5,36)$，误差范围变大，选 A。

这里的教训有两条。凡是用到权重或距离的比较，都要写明所用的单位或参考范围。归一化不是中性的操作，它把“一单位误差值多少钱”换成了“各目标范围的一格彼此相当”，这也是一种偏好，只是不那么显眼。参考范围最好由被信任的方案决定，并在结果中报告，不让被支配的候选参与定尺度。

26.1 多目标问题
26.2 标量化
26.2.1 加权和
26.2.2 阈值约束
26.2.3 参考点方法
26.3 最优解的判别
26.4 多梯度下降
26.5 前沿的计算
26.6 前沿的评价
26.7 本章小结

26.2 标量化

决策者往往能说出某种偏好：一项指标值多少钱，或者预算不能超过多少，或者希望各项都接近某个水平。有了偏好，就可以把多目标问题改写成单目标问题，再调用前面各章的方法。这样的改写称为**标量化**（scalarization）。

每种改写的解是不是 Pareto 最优点？改写的参数变化时，能到达前沿上的哪些点？要记住的一点是，标量化问题的解只代表这一次写下的偏好，不是“多目标问题的解”。

26.2.1 加权和

最直接的偏好是价格：给每个目标定一个单价，只看总价。这一小节研究按总价选出的方案有什么性质，以及扫遍所有价格能不能走遍前沿。

定义与直观　取权重 $\boldsymbol{w}$ 属于单纯形

$$\Delta_m = \left\{ \boldsymbol{w} \in \mathbb{R}^m \,:\, w_i \geq 0,\ \sum_{i=1}^{m} w_i = 1 \right\},$$

求解

$$\min_{\boldsymbol{x} \in \boldsymbol{C}} \sum_{i=1}^{m} w_i f_i(\boldsymbol{x}). \tag{26.10}$$

这种做法称为**加权和法**（weighted-sum method）。两个目标时，把权重简写成 $\boldsymbol{w} = (w, 1-w)$，$w \in [0,1]$。

在目标平面上，总价相同的点组成一条法向为 $\boldsymbol{w}$ 的直线。最小化总价，就是让这条直线从左下方平移过来，直到第一次碰到可达目标集。碰到的点就是解，这条直线称为**支撑线**（supporting line）。下面的讨论几乎都从这幅图景得来，见图 26.8。

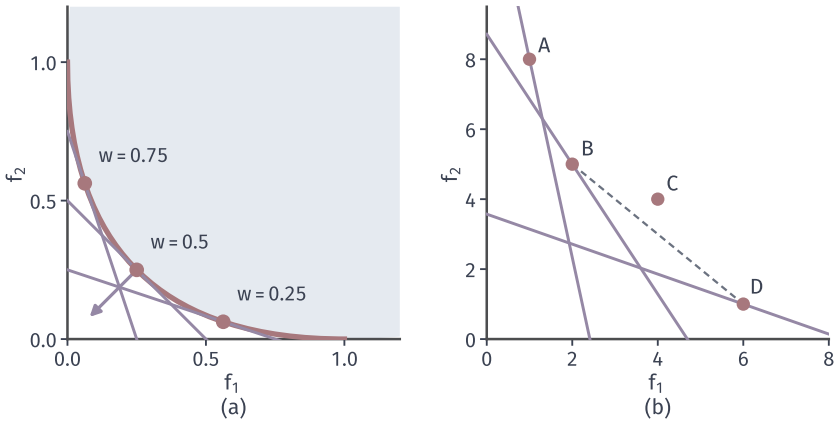


图 26.8 加权和的支撑线，紫线是最低的等总价线。(a) 式 (26.4)的前沿（红色），$w = 0.25, 0.5, 0.75$ 时的切点；紫色箭头是 $w = 0.5$ 时的负法向，指向总价下降的方向。(b) 式 (26.3)中 A, B, C, D 四点，$w = 0.3, 0.65, 0.85$ 的支撑线分别经过 D, B, A；C 在虚线 BD 上方，任何支撑线都先碰到别的点。

加权和的解与 Pareto 最优 解的性质由权重的符号决定。权重全正时，支配者在总价上一定严格更便宜，所以解不会被支配。权重有零时，零权重目标的严格改善不计入总价，只能得到较弱的结论。

定理 26.3 加权和的解 设 $\boldsymbol{x}^\star$ 是问题 (26.10)的全局最优解。

1. 若所有 $w_i > 0$，则 $\boldsymbol{x}^\star$ 是 Pareto 最优点。
2. 若 $\boldsymbol{w} \in \Delta_m$，则 $\boldsymbol{x}^\star$ 是弱 Pareto 最优点。
3. 若 $\boldsymbol{w} \in \Delta_m$，且 $\boldsymbol{x}^\star$ 是问题 (26.10)的唯一全局最优解，则 $\boldsymbol{x}^\star$ 是 Pareto 最优点。

证明 记 $\phi(\boldsymbol{x}) = \sum_i w_i f_i(\boldsymbol{x})$。

(1) 若 $\boldsymbol{u} \in \boldsymbol{C}$ 支配 $\boldsymbol{x}^\star$，则 $w_i f_i(\boldsymbol{u}) \le w_i f_i(\boldsymbol{x}^\star)$ 对所有 i 成立。对 $f_i(\boldsymbol{u}) < f_i(\boldsymbol{x}^\star)$ 的那个 i，由 $w_i > 0$ 得严格不等号。逐项相加得 $\phi(\boldsymbol{u}) < \phi(\boldsymbol{x}^\star)$，矛盾。

(2) 若 $\boldsymbol{u} \in \boldsymbol{C}$ 使 $f_i(\boldsymbol{u}) < f_i(\boldsymbol{x}^\star)$ 对所有 i 成立，由于 $\boldsymbol{w} \in \Delta_m$，至少有一个 $w_i > 0$，相加仍得 $\phi(\boldsymbol{u}) < \phi(\boldsymbol{x}^\star)$，矛盾。

(3) 若 $\boldsymbol{u} \in \boldsymbol{C}$ 支配 $\boldsymbol{x}^\star$，由 $w_i \ge 0$ 得 $\phi(\boldsymbol{u}) \le \phi(\boldsymbol{x}^\star)$，所以 $\boldsymbol{u}$ 也是全局最优解。由唯一性 $\boldsymbol{u} = \boldsymbol{x}^\star$，这与“至少一项严格更小”矛盾。 ■

三条结论都只用到全局最优性，没有用到凸性。定理的第 1 条马上回答了第 26.1.2节留下的存在性问题。

定理 26.4　Pareto 最优点的存在　设 $\boldsymbol{C}$ 非空紧，各 f_i 在 $\boldsymbol{C}$ 上连续，则 Pareto 解集非空。

证明　取 $w_i = 1/m$。连续函数 $\sum_i w_i f_i$ 在非空紧集上取得最小值，这是第 1章的结论。由定理 26.3的第 1 条，最小点是 Pareto 最优点。 ■

第 26.1.2节的反例中 $\boldsymbol{C} = (0, 1]$ 不闭，紧性不成立。

连续例：权重到前沿的对应　对例 (26.4)，由式 (26.6)，总价是

$$w\,s^2 + (1-w)(1-s)^2 + \tfrac{1}{2}r^2.$$

先取 $r = 0$，再对 s 求导令其为零：

$$2ws - 2(1-w)(1-s) = 0.$$

解得 $s = 1 - w$，也就是 $\boldsymbol{x} = (w, 1-w)$，对应前沿上的点

$$\big(f_1, f_2\big) = \big((1-w)^2,\ w^2\big). \tag{26.11}$$

前沿在该点的斜率也能算出来。由式 (26.7)，$\mathrm{d}f_2/\mathrm{d}f_1 = -(1-s)/s = -w/(1-w)$，正好等于等总价线的斜率。价格比决定了切点的位置，这就是图 26.8(a) 显示的情况。

例如 $w = 1/2$ 时，解是 $\boldsymbol{x} = (1/2, 1/2)$，目标是 $(1/4, 1/4)$。端点 $\boldsymbol{x} = \boldsymbol{a}$ 只有在 $w = 1$ 时才能得到，此时权重有零，但解唯一，由定理 26.3的第 3 条它仍是 Pareto 最优点。

有限例：下包络　对式 (26.3)，每个候选的总价是 w 的一次函数：

$$A:\ 8 - 7w, \quad B:\ 5 - 3w, \quad C:\ 4,$$
$$D:\ 1 + 5w, \quad E:\ 6 - w, \quad F:\ 1 + 6w.$$

图 26.9把六条直线画在一起，每个 w 上的最小值组成红色的下包络。$w < 1/2$ 时 D 最便宜，$1/2 < w < 3/4$ 时 B 最便宜，$w > 3/4$ 时 A 最便宜。

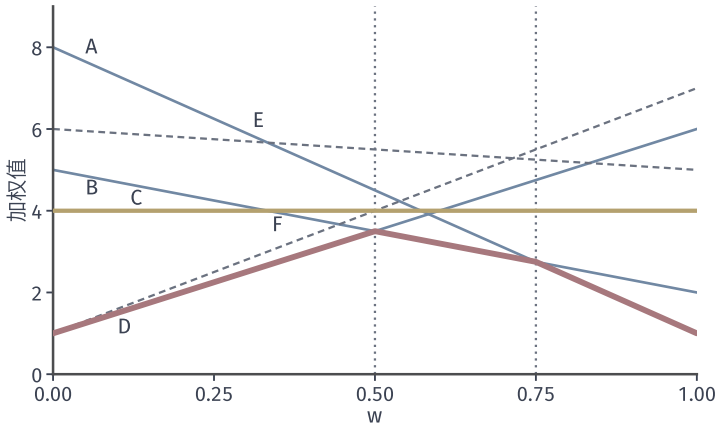


图 26.9 六个候选的总价随权重 w 的变化。红线是下包络，其转折点在 $w = 1/2$ 和 $w = 3/4$。黄线是 C，它始终在下包络之上。虚线是被支配的 E 和 F。

C 虽然是 Pareto 最优点，却永远选不上。要比 B 便宜，需要 $4 \le 5 - 3w$，即 $w \le 1/3$；要比 D 便宜，需要 $4 \le 1 + 5w$，即 $w \ge 3/5$。两个要求不能同时满足。

几何上，线段 BD 在 $f_1 = 4$ 处的高度是 3，而 C 的高度是 4，C 位于线段上方。能被某组权重选中的 Pareto 点称为**支撑点**（supported point），C 不是支撑点。

下包络也说明了解的跳变：w 从小到大扫过 $1/2$ 时，答案从 D 直接跳到 B，两者的总价都是 3.5；扫过 $3/4$ 时从 B 跳到 A，总价都是 2.75。

零权重的情形也可以在这里看到。$w = 0$ 时总价就是误差，D 和 F 都等于 1，并列最优，而 F 被 D 支配。定理 26.3只保证 F 是弱 Pareto 最优点，这个结论不能再加强。

凸问题：非负权重足够覆盖 前面的例子表明，非凸时支撑点可能不是全部。凸性保证的是，不存在 C 那样藏在凹陷里的点。

> **定理 26.5 凸问题的支撑权重** 设 $\boldsymbol{C}$ 凸，各 f_i 在 $\boldsymbol{C}$ 上凸。若 $\bar{\boldsymbol{x}}$ 是全局弱 Pareto 最优点，则存在 $\boldsymbol{w} \in \Delta_m$，使 $\bar{\boldsymbol{x}}$ 是问题 (26.10)的全局最优解。

证明的思路是把可达集合向右上方“加厚”，使它成为凸集，再用超平面把它与 $\bar{\boldsymbol{y}}$ 左下方的点隔开。所用的严格分离定理在第 18章已经证明：一点若不在闭凸集中，就存在超平面把二者严格分开。

证明　记 $\bar{\boldsymbol{y}} = \boldsymbol{f}(\bar{\boldsymbol{x}})$，记全 1 向量为 $\mathbf{1}$。令

$$\boldsymbol{A} = \{\boldsymbol{f}(\boldsymbol{x}) + \boldsymbol{t} : \boldsymbol{x} \in \boldsymbol{C},\ \boldsymbol{t} \geq \mathbf{0}\}.$$

先说明 $\boldsymbol{A}$ 凸。取 $\boldsymbol{f}(\boldsymbol{x}) + \boldsymbol{t}$ 与 $\boldsymbol{f}(\boldsymbol{x}') + \boldsymbol{t}'$，$\gamma \in [0,1]$。由 f_i 凸，

$$\boldsymbol{f}(\gamma\boldsymbol{x} + (1-\gamma)\boldsymbol{x}') \leq \gamma\boldsymbol{f}(\boldsymbol{x}) + (1-\gamma)\boldsymbol{f}(\boldsymbol{x}'),$$

差额并入 $\boldsymbol{t}$ 的凸组合，所以这两点的凸组合仍在 $\boldsymbol{A}$ 中。于是闭包 $\operatorname{cl}\boldsymbol{A}$ 是闭凸集。

对 $\epsilon > 0$，点 $\boldsymbol{z}_\epsilon = \bar{\boldsymbol{y}} - \epsilon\mathbf{1}$ 不在 $\operatorname{cl}\boldsymbol{A}$ 中。否则有 $\boldsymbol{A}$ 中的点列趋于 $\boldsymbol{z}_\epsilon$，其中某一点的每个分量都严格小于 $\bar{\boldsymbol{y}}$ 的相应分量。这个点形如 $\boldsymbol{f}(\boldsymbol{x}) + \boldsymbol{t}$，于是 $f_i(\boldsymbol{x}) < \bar{y}_i$ 对所有 i 成立，与弱 Pareto 最优矛盾。

由严格分离定理，取单位向量 $\boldsymbol{c}_\epsilon$，使对所有 $\boldsymbol{x} \in \boldsymbol{C}$，$\boldsymbol{t} \geq \mathbf{0}$，

$$\langle \boldsymbol{c}_\epsilon, \boldsymbol{f}(\boldsymbol{x}) + \boldsymbol{t}\rangle > \langle \boldsymbol{c}_\epsilon, \boldsymbol{z}_\epsilon\rangle.$$

若 $\boldsymbol{c}_\epsilon$ 有负分量，让 $\boldsymbol{t}$ 的相应分量趋于无穷，左端趋于 $-\infty$，矛盾，所以 $\boldsymbol{c}_\epsilon \geq \mathbf{0}$。

单位球面紧，取 $\epsilon \downarrow 0$ 的子列使 $\boldsymbol{c}_\epsilon \to \boldsymbol{c}$。则 $\boldsymbol{c} \geq \mathbf{0}$，$\boldsymbol{c} \neq \mathbf{0}$。在上式中取 $\boldsymbol{t} = \mathbf{0}$，令 $\epsilon \downarrow 0$，得到

$$\langle \boldsymbol{c}, \boldsymbol{f}(\boldsymbol{x})\rangle \geq \langle \boldsymbol{c}, \bar{\boldsymbol{y}}\rangle \quad \text{对所有 } \boldsymbol{x} \in \boldsymbol{C}.$$

令 $\boldsymbol{w} = \boldsymbol{c}/\sum_i c_i \in \Delta_m$，上式就是 $\bar{\boldsymbol{x}}$ 最小化 $\sum_i w_i f_i$。 ■

定理的结论是“存在非负权重”，不是“存在全正权重”。例 (26.4)的端点 $\boldsymbol{a}$ 只有权重 $(1,0)$ 能选中，就说明全正的要求一般做不到。定理的条件也不能去掉，图 26.10的两个例子都不满足凸性。

非凸前沿上的遗漏　第三个例子是一个一元问题：$x \in [0,1]$，

$$f_1(x) = x, \qquad f_2(x) = 1 - x^2. \tag{26.12}$$

f_1 递增，f_2 递减，所以每个 x 都是 Pareto 最优点，前沿是向右上方鼓起的抛物线。加权目标是

$$w\,x + (1-w)(1-x^2).$$

它是 x 的凹函数，在区间上的最小值只能在端点取到，分别是 $x = 0$ 时的 $1 - w$ 和 $x = 1$ 时的 w。

26.1 多目标问题
26.2 标量化
26.2.1 加权和
26.2.2 阈值约束
26.2.3 参考点方法
26.3 最优解的判别
26.4 多梯度下降
26.5 前沿的计算
26.6 前沿的评价
26.7 本章小结

于是 $w > 1/2$ 时解是 $x = 0$，$w < 1/2$ 时解是 $x = 1$，$w = 1/2$ 时两端并列。无论权重取什么，中间的方案都选不到。图 26.10(a) 中三条紫线都只能碰到两个端点。

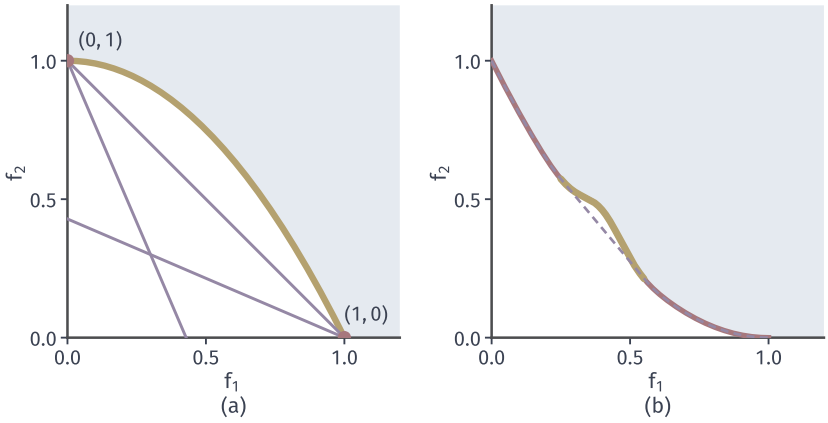


图 26.10　加权和遗漏的前沿。(a) 式 (26.12)的前沿，紫线是 $w = 0.3, 0.5, 0.7$ 的支撑线，都只碰到端点（红点），黄色段上的点都选不到。(b) 带凹陷的前沿 $f_2 = (1 - f_1)^2 + 0.1\exp(-((f_1 - 0.4)/0.1)^2)$，紫色虚线是它的下凸包，黄色段 $(0.25 < f_1 < 0.55)$ 位于凸包上方，选不到。

现实中的前沿常常只有一段凹陷。图 26.10(b) 中，前沿由一个下凸的主体和一个小鼓包组成。任何方向的支撑线都不会碰到黄色段内部，紫色虚线就是它的**下凸包**（lower convex hull），凹陷中的点都比这条线高。从图上也可以知道，权重一旦扫过黄色段两端所对应的斜率，答案就从一端跳到另一端。

所以，“扫描权重”只能得到支撑点。对非凸问题，这可能漏掉前沿的大部分。

26.2.2 阈值约束

很多需求本来就不是价格，而是硬指标：预算不超过某个数，在此前提下误差尽量小。这一小节把这种需求写成约束，研究它和加权和有什么不同。

定义　保留第 j 个目标作为被最小化的量，其余目标用阈值 τ_i 限制：

$$\min_{\boldsymbol{x}\in\boldsymbol{C}} f_j(\boldsymbol{x}) \quad \text{s.t.} \quad f_i(\boldsymbol{x}) \le \tau_i,\ i \ne j. \tag{26.13}$$

这种做法称为**阈值约束法**（ε-constraint method）。这是一个普通的约束优化问题，第 17章的最优性条件和前一部分各章的求解方法都能直接用上。

在目标平面上，两个目标时阈值约束是一条竖线 $f_1 \le \tau$，竖线左侧的部分是可行的，问题就是在其中找最低点。这条竖线不需要从外部支撑可达集合，所以能插进前沿的凹陷里。

解的性质　和加权和不同，这里的结论有反方向的一半，而且不需要凸性。

定理 26.6　阈值约束的解　固定 j 与阈值 τ_i，$i \neq j$。

1. 问题 (26.13)的每个全局最优解都是弱 Pareto 最优点；若全局最优解唯一，它是 Pareto 最优点。
2. 若 $\bar{\boldsymbol{x}}$ 是 Pareto 最优点，取 $\tau_i = f_i(\bar{\boldsymbol{x}})$，$i \neq j$，则 $\bar{\boldsymbol{x}}$ 是问题 (26.13)的全局最优解。
3. 设 $\boldsymbol{S}$ 是问题 (26.13)的全局最优解集。若 $\tilde{\boldsymbol{x}}$ 在 $\boldsymbol{S}$ 上最小化 $\sum_{i\neq j} f_i$，则 $\tilde{\boldsymbol{x}}$ 是 Pareto 最优点。

证明　(1) 设 $\hat{\boldsymbol{x}}$ 是全局最优解。若 $\boldsymbol{u} \in \boldsymbol{C}$ 的各目标都严格小于 $\hat{\boldsymbol{x}}$，则 $f_i(\boldsymbol{u}) < f_i(\hat{\boldsymbol{x}}) \le \tau_i$，$\boldsymbol{u}$ 可行，而 $f_j(\boldsymbol{u}) < f_j(\hat{\boldsymbol{x}})$，矛盾。

若 $\hat{\boldsymbol{x}}$ 是唯一全局最优解，设 $\boldsymbol{u}$ 支配 $\hat{\boldsymbol{x}}$。同样 $\boldsymbol{u}$ 可行，且 $f_j(\boldsymbol{u}) \le f_j(\hat{\boldsymbol{x}})$，所以 $\boldsymbol{u}$ 也是全局最优解。由唯一性 $\boldsymbol{u} = \hat{\boldsymbol{x}}$，与支配矛盾。

(2)$\bar{\boldsymbol{x}}$ 满足 $f_i(\bar{\boldsymbol{x}}) \le \tau_i$，可行。若可行点 $\boldsymbol{u}$ 使 $f_j(\boldsymbol{u}) < f_j(\bar{\boldsymbol{x}})$，再由可行性 $f_i(\boldsymbol{u}) \le \tau_i = f_i(\bar{\boldsymbol{x}})$，$\boldsymbol{u}$ 支配 $\bar{\boldsymbol{x}}$，矛盾。

(3) 设 $\boldsymbol{u} \in \boldsymbol{C}$ 支配 $\tilde{\boldsymbol{x}}$。各约束下 $f_i(\boldsymbol{u}) \le f_i(\tilde{\boldsymbol{x}}) \le \tau_i$，$\boldsymbol{u}$ 可行；又 $f_j(\boldsymbol{u}) \le f_j(\tilde{\boldsymbol{x}})$，所以 $\boldsymbol{u} \in \boldsymbol{S}$，且 $f_j(\boldsymbol{u}) = f_j(\tilde{\boldsymbol{x}})$。于是严格减小的分量在 $i \neq j$ 中，$\sum_{i\neq j} f_i(\boldsymbol{u}) < \sum_{i\neq j} f_i(\tilde{\boldsymbol{x}})$，矛盾。 ■

第 2 条说的是，每个 Pareto 点都能被某组阈值选中，即使它不是支撑点。第 3 条给出处理并列最优解的办法：先满足阈值并最小化 f_j，再在并列的解中比较其余目标。这种分步择优也叫字典序的处理。

有限例与不可行　在式 (26.3)上取 $j = 2$，以成本为预算 τ，求误差的最小值

$$v(\tau) = \min\{f_2 : f_1 \le \tau\}. \tag{26.14}$$

逐段比较得到：

$$
v(\tau)=\begin{cases}\text{不可行}, & \tau<1,\\ 8\,(A), & 1\le\tau<2,\\ 5\,(B), & 2\le\tau<4,\\ 4\,(C), & 4\le\tau<6,\\ 1\,(D), & \tau\ge 6.\end{cases}
$$

这张表说明了三件事。阈值过紧时问题不可行，应当如实报告“不存在满足要求的方案”，不要输出一个违反约束的点。预算扫过 4 时选中了 C，这个点加权和永远选不到。$\tau\ge 7$ 时 D 与 F 并列，而 F 被 D 支配，这时按定理 26.6的第 3 条再比较成本，就排除了 F。

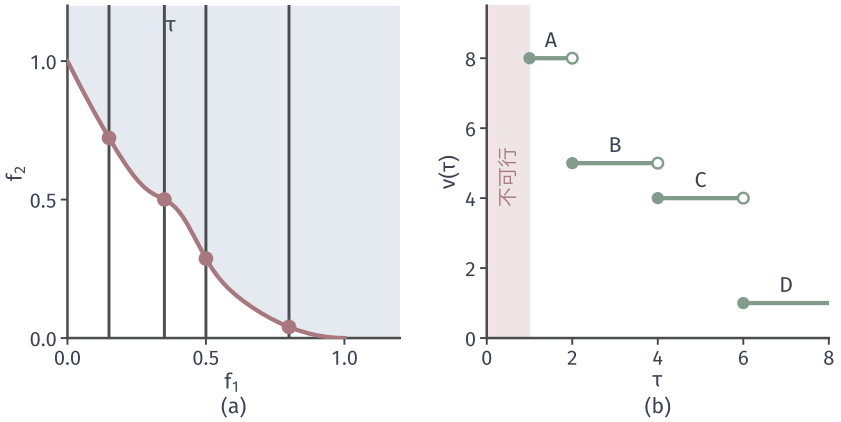


图 26.11　阈值约束的扫描。(a) 图 26.10(b) 的前沿，深灰竖线是四个阈值，红点是相应的解，其中两个点在加权和选不到的凹陷段内。(b) 有限例的 $v(\tau)$，实心点属于该段，空心点不属于；粉色区域不可行，字母是选中的方案。

图 26.11(a) 显示，阈值从左向右扫过时，解沿整条前沿移动。代价是每次都要解一个带约束的问题，这比加权和难：加权和只是一个无约束问题，这里多了一个可能起作用的约束。

阈值与价格的联系　阈值 τ 和价格 w 看起来是两种语言，通过乘子可以把它们联系起来。把例 (26.4)写成 $j=2$ 的阈值问题，

$$
\min\ f_2(\boldsymbol{x})\quad \text{s.t.}\quad f_1(\boldsymbol{x})\le\tau,
$$

约束起作用时，KKT 驻定条件（第 17章）要求

$$
\nabla f_2(\boldsymbol{x})+\lambda\nabla f_1(\boldsymbol{x})=\mathbf{0},\qquad \lambda\ge 0. \tag{26.15}
$$

式 (26.15)除以 $1+\lambda$，就是权重 $\boldsymbol{w}=(\lambda,1)/(1+\lambda)$ 的加权和的驻定条件。乘子 λ 就是目标 f_1 相对于 f_2 的价格。

具体计算。在解的线段上 $f_1=s^2=\tau$，所以 $s=\sqrt{\tau}$，且 $r=0$。式 (26.15)沿线段方向的分量给出 $(s-1)+\lambda s=0$，于是

$$\lambda(\tau)=\frac{1-\sqrt{\tau}}{\sqrt{\tau}},\qquad 0<\tau\le 1. \tag{26.16}$$

例如 $\tau=1/4$ 时，$s=1/2$，$\lambda=1$，权重正是 $(1/2,1/2)$，解与式 (26.11)中 $w=1/2$ 的解相同。

式 (26.16)也描述了 τ 增大时价格怎样变化。由式 (26.7)，最优值 $v(\tau)=(1-\sqrt{\tau})^2$，求导得

$$v'(\tau)=-\frac{1-\sqrt{\tau}}{\sqrt{\tau}}=-\lambda(\tau).$$

放宽一单位阈值，最优值下降 λ，这与第 19章乘子是影子价格的结论一致。图 26.12画出了这一点。τ 接近 0 时 λ 趋于无穷，$\tau\ge 1$ 时约束不再起作用，$\lambda=0$，解停在 $\boldsymbol{b}$。

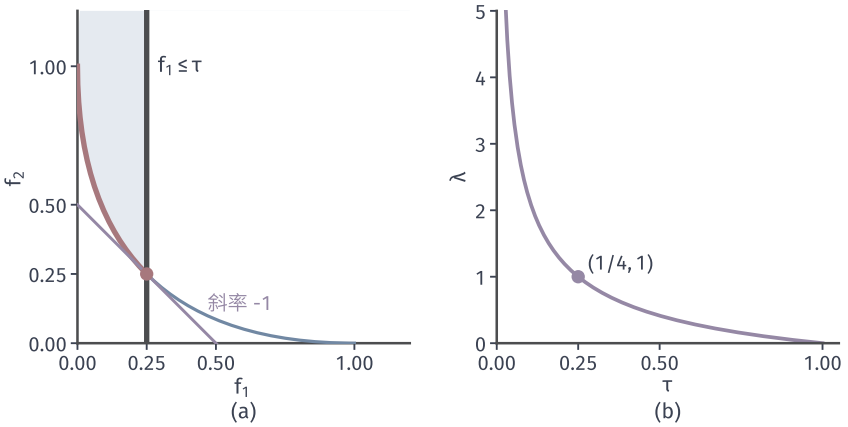


图 26.12 阈值与价格，例 (26.4)。(a) 深灰竖线是阈值 $f_1\le 1/4$，可行部分为左侧浅蓝区域，红色段是可行的前沿，红点是解；紫线是前沿在该点的切线，斜率 $-\lambda=-1$。(b) 乘子随阈值的变化，式 (26.16)。

这种对应只在问题有相应结构时才是一一对应。非凸时，凹陷中的解仍满足式 (26.15)，但它只是相应加权和的驻定点，不是最小点。阈值问题的解能到达加权和到不了的地方，正是因为这里的约束替代了全局的比较。

并列最优解 前沿出现水平段时，阈值问题的解不唯一。图 26.13中，阈值 τ 落在底部水平边的范围内，$\boldsymbol{z}'$ 和 $\boldsymbol{z}$ 的 f_2 都等于最小值，黄色线段上的点都是最优解。$\boldsymbol{z}$ 被 $\boldsymbol{z}'$ 支配。

26.1 多目标问题
26.2 标量化
26.2.1 加权和
26.2.2 阈值约束
26.2.3 参考点方法
26.3 最优解的判别
26.4 多梯度下降
26.5 前沿的计算
26.6 前沿的评价
26.7 本章小结

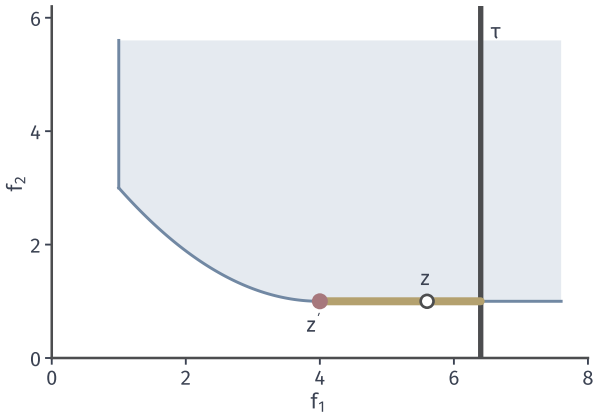


图 26.13 阈值约束的并列最优解。深灰竖线是阈值，黄色线段是 $\min\{f_2 : f_1 \le \tau\}$ 的全部解的目标值。空心点 $\boldsymbol{z}$ 是弱 Pareto 最优点，红点 $\boldsymbol{z}'$ 是在并列解中进一步最小化 f_1 后得到的 Pareto 最优点。

求解器一般只返回并列解中的某一个，不一定是 $\boldsymbol{z}'$。所以，只要阈值问题的解不能确认唯一，就要做第二阶段的择优，否则报告的只是一个弱 Pareto 最优点。

26.2.3 参考点方法

有时决策者说的既不是价格，也不是预算，而是希望各项指标都接近某个水平。这一小节把这种需求写成到参考点的最大偏差，它能选中加权和选不到的点，又不必增加约束。

定义 设各目标在 $\boldsymbol{C}$ 上有有限下界，取**参考点**（reference point）$\boldsymbol{z}$，使 $z_i < \inf_{\boldsymbol{C}} f_i$ 对所有 i 成立。再取权重 $w_i > 0$，最小化带权的最大偏差：

$$\min_{\boldsymbol{x}\in\boldsymbol{C}} \max_{1\le i\le m} w_i\bigl(f_i(\boldsymbol{x}) - z_i\bigr). \tag{26.17}$$

这种做法称为**加权 Chebyshev 标量化**（weighted Chebyshev scalarization）。

式 (26.17)的直观含义是，目标被缩放后，看离参考点最远的一项。下水平集是以 $\boldsymbol{z}$ 为左下角的长方形，边长比由权重决定。随着水平增大，长方形的右上角沿着从 $\boldsymbol{z}$ 出发、方向为 $(1/w_1, \dots, 1/w_m)$ 的射线向外移动。长方形第一次碰到可达集合时的水平，就是最优值。

长方形的右上角尖尖地探出去，而加权和的直线是平的。平的直线碰不到凹陷，尖的角能探进去，见图 26.14。

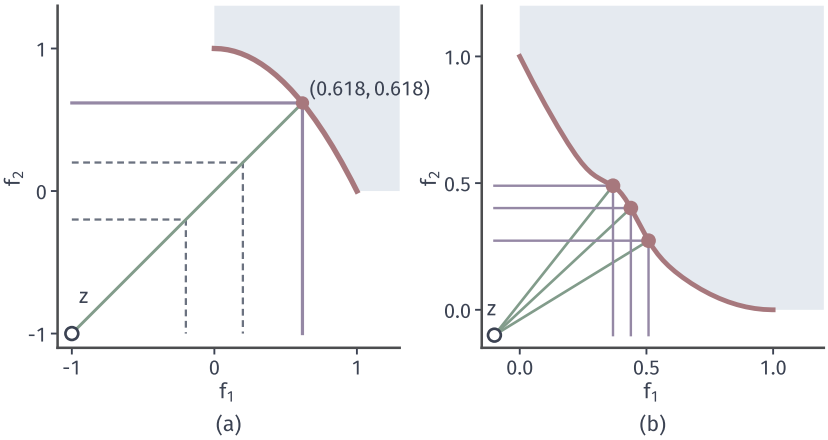


图 26.14 加权 Chebyshev 的水平集，空心点是参考点 $\boldsymbol{z}$，绿线是沿 $(1/w_1, 1/w_2)$ 的射线。(a) 式 (26.12)的前沿，$\boldsymbol{z} = (-1, -1)$，$\boldsymbol{w} = (1/2, 1/2)$；灰色虚线是较低水平的长方形边界，紫线是最优水平，角落碰到 $(0.618, 0.618)$。(b) 图 26.10(b) 的前沿，$\boldsymbol{z} = (-0.1, -0.1)$，三组权重的解都在凹陷段内，紫线是相应的最优长方形边界。

解的性质 先看式 (26.17)的解是什么点，再看能选到哪些点。

定理 26.7 加权 Chebyshev 的解 设 $\boldsymbol{z}$ 严格低于各目标的下确界。

1. 对任意 $w_i > 0$，问题 (26.17)的全局最优解都是弱 Pareto 最优点。
2. 若 $\bar{\boldsymbol{x}}$ 是弱 Pareto 最优点，取

$$w_i = \frac{1}{f_i(\bar{\boldsymbol{x}}) - z_i}, \tag{26.18}$$

   则 $\bar{\boldsymbol{x}}$ 是问题 (26.17)的全局最优解。
3. 设 $\boldsymbol{S}$ 是问题 (26.17)的全局最优解集。若 $\tilde{\boldsymbol{x}}$ 在 $\boldsymbol{S}$ 上最小化 $\sum_i f_i$，则 $\tilde{\boldsymbol{x}}$ 是 Pareto 最优点。

证明 记 $\psi(\boldsymbol{x}) = \max_i w_i(f_i(\boldsymbol{x}) - z_i)$。

(1) 设 $\boldsymbol{x}^\star$ 是全局最优解。若 $\boldsymbol{u}$ 的各目标都严格小于 $\boldsymbol{x}^\star$，由 $w_i > 0$，对所有 i 有

$$w_i(f_i(\boldsymbol{u}) - z_i) < w_i(f_i(\boldsymbol{x}^\star) - z_i) \le \psi(\boldsymbol{x}^\star).$$

有限个严格不等式取最大仍严格，$\psi(\boldsymbol{u}) < \psi(\boldsymbol{x}^\star)$，矛盾。

(2) 由 $z_i < \inf f_i$，式 (26.18)中分母为正，$w_i > 0$，并且

$$w_i\big(f_i(\bar{\boldsymbol{x}}) - z_i\big) = 1 \quad \text{对所有 } i,$$

所以 $\psi(\tilde{\boldsymbol{x}})=1$。若有 $\boldsymbol{u}$ 使 $\psi(\boldsymbol{u})<1$，则 $w_i(f_i(\boldsymbol{u})-z_i)<1$ 对所有 i 成立，代入 w_i 的定义得 $f_i(\boldsymbol{u})<f_i(\tilde{\boldsymbol{x}})$ 对所有 i 成立，与弱 Pareto 最优矛盾。

(3) 设 $\boldsymbol{u}$ 支配 $\tilde{\boldsymbol{x}}$。各项 $f_i(\boldsymbol{u})\le f_i(\tilde{\boldsymbol{x}})$，由 $w_i>0$ 得 $\psi(\boldsymbol{u})\le\psi(\tilde{\boldsymbol{x}})$，所以 $\boldsymbol{u}\in\boldsymbol{S}$。又有一项严格减小，$\sum_i f_i(\boldsymbol{u})<\sum_i f_i(\tilde{\boldsymbol{x}})$，矛盾。 ■

$\boldsymbol{z}$ 严格低于下确界的条件保证了第 2 条的权重有限且为正。第 2 条不需要凸性，这也是这种标量化比加权和强的地方：调整权重可以选中每一个弱 Pareto 最优点，当然也包括每一个 Pareto 最优点。

算一个连续的例子 对式 (26.12)取 $\boldsymbol{z}=(-1,-1)$，它低于两个目标的下确界 0。取 $\boldsymbol{w}=(1/2,1/2)$，目标是

$$\psi(x)=\frac{1}{2}\max\{x+1,\ 2-x^2\}.$$

$x+1$ 递增，$2-x^2$ 递减，最大值的最小点在两者相等处：

$$x+1=2-x^2,\quad \text{即}\quad x^2+x-1=0.$$

解得 $x=(\sqrt{5}-1)/2\approx 0.618$，目标向量也是 $(0.618,0.618)$，这是加权和选不到的中间点。

有限例：并列最优仍会发生 在式 (26.3)上取 $\boldsymbol{z}=(0,0)$，它严格低于下确界 $(1,1)$。取 $\boldsymbol{w}=(1/2,1/2)$，各候选的 ψ 值为

$$A:\ 4,\quad B:\ 2.5,\quad C:\ 2,\quad D:\ 3,\quad E:\ 3,\quad F:\ 3.5.$$

最小的是 C，这正是加权和选不到的方案，见图 26.15(a)。

再取 $\boldsymbol{w}=(0.1,0.9)$，各候选的 ψ 值为

$$A:\ 7.2,\quad B:\ 4.5,\quad C:\ 3.6,\quad D:\ 0.9,\quad E:\ 5.4,\quad F:\ 0.9.$$

D 与 F 并列最小。此时第二个目标的偏差决定了最大值，第一个目标的差别被 max 吞掉了，F 虽然被 D 支配，却同样最优，见图 26.15(b)。按定理 26.7的第 3 条再比较 $\sum_i f_i$，D 的和是 7，F 的和是 8，排除了 F。

26.1 多目标问题
26.2 标量化
26.3 最优解的判别
26.3.1 共同下降方向
26.3.2 可行方向
26.4 多梯度下降
26.5 前沿的计算
26.6 前沿的评价
26.7 本章小结

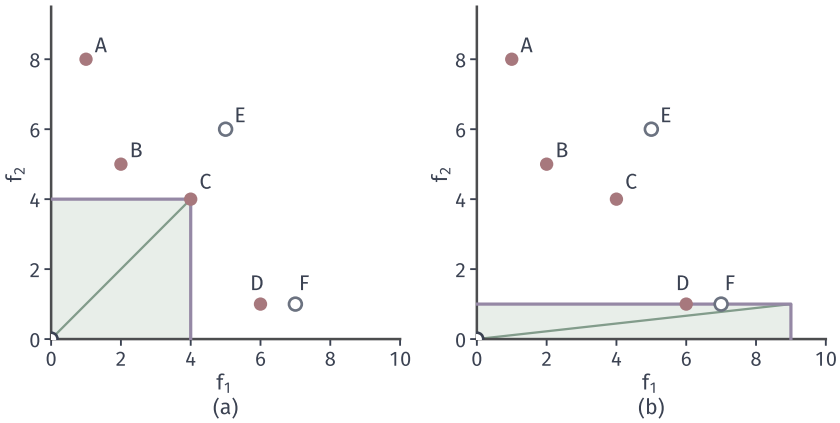


图 26.15 有限候选上的加权 Chebyshev，参考点 $\boldsymbol{z} = (0, 0)$（空心点在原点）。绿色长方形是最优水平的下水平集，紫线是其右上边界。(a)$\boldsymbol{w} = (1/2, 1/2)$，长方形的角落碰到 C。(b)$\boldsymbol{w} = (0.1, 0.9)$，长方形的上边同时碰到 D 和 F，F 是并列的弱 Pareto 最优点。

三种写法的比较 表 26.1汇总了三种标量化。没有哪一种处处占优。加权和最容易求解，但只能到达支撑点；阈值约束和加权 Chebyshev 能到达每个 Pareto 点，代价是多了约束或非光滑的 max。后者可以用第 20章一类的上图改写来处理：引入变量 t，在约束 $w_i(f_i(\boldsymbol{x}) - z_i) \le t$ 下最小化 t。

表 26.1 三种标量化的比较。“解的保证”指全局最优解的性质。

方法	解的保证	可达的点	并列情形
加权和	全正权：Pareto	支撑点	权重有零时
阈值约束	弱 Pareto	全部 Pareto 点	水平段上
加权 Chebyshev	弱 Pareto	全部弱 Pareto 点	水平段或竖直段

这些结论的更多变形可以查阅凸优化专著中多准则优化一节[1]。无论用哪一种，所得的都只是一次偏好下的解。要给决策者看一组候选，还需要第 26.5节的组织方式。

[1] S. Boyd, L. Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004

26.3 最优解的判别

标量化回答的是“给定偏好求一个解”。这一节换一个问法：手里已经有一个候选点，只看它附近的导数信息，能否判断它值不值得继续改进？

单目标问题中，这个问题由“存在下降方向”来回答。多目标问题中对应的问题是：是否存在一个可行的小步，使所有目标都下降？本节先在无约束内点回答，再加上约束。全节都要把两种结论分开：不存在共同下降方向是一个局部的必要条件，它要成为全局 Pareto 最优的证据，还需要凸性和权重条件。

26.1 多目标问题
26.2 标量化
26.3 最优解的判别
26.3.1 共同下降方向
26.3.2 可行方向
26.4 多梯度下降
26.5 前沿的计算
26.6 前沿的评价
26.7 本章小结

26.3.1 共同下降方向

设 $\boldsymbol{x}$ 是 $\boldsymbol{C}$ 的内点，各 f_i 在 $\boldsymbol{x}$ 处可微，记

$$\boldsymbol{g}_i = \nabla f_i(\boldsymbol{x}), \qquad i = 1, \dots, m.$$

我们想知道，从 $\boldsymbol{x}$ 出发能不能让全部目标一起变小。

方向的定义 一个方向 $\boldsymbol{d}$ 若满足

$$\langle \boldsymbol{g}_i, \boldsymbol{d} \rangle < 0 \quad \text{对所有 } i = 1, \dots, m, \tag{26.19}$$

就称为**共同下降方向**（common descent direction）。由一阶 Taylor 展开，沿这样的 $\boldsymbol{d}$ 走足够小的一步，每个目标都严格下降，当前点就被支配了。

每个不等式要求 $\boldsymbol{d}$ 落在以 $\boldsymbol{g}_i$ 为法向的一个开半空间内，所有这些半空间的公共部分就是全部共同下降方向。图 26.16(a) 中两个梯度夹角小于 180°，绿色楔形就是这个公共部分。

等高线上的直观是：站在山坡上，每个目标各有一个下山的半平面。几个半平面还有公共的部分，就能一步同时往几座山的下坡方向走。公共部分消失时，不管往哪里走，至少有一个目标的一阶变化不是下降。

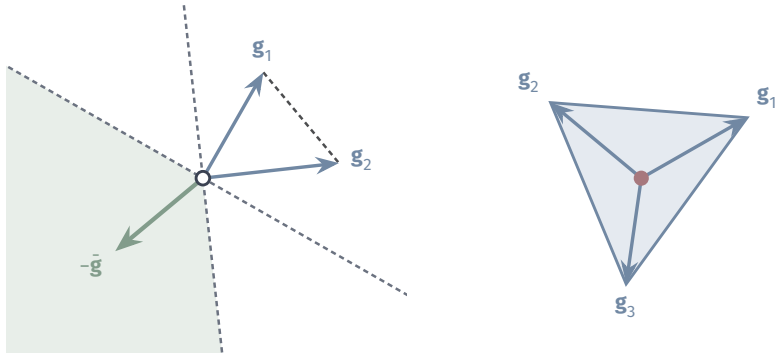


图 26.16 共同下降方向与梯度的凸包，空心点和红点是原点。(a) 两个梯度的凸包是虚线线段，不含原点；两条灰色虚线分别垂直于 $\boldsymbol{g}_1, \boldsymbol{g}_2$，绿色楔形是共同下降方向。(b) 三个梯度的凸包是浅蓝三角形，原点（红点）在其内部，此时不存在共同下降方向。

用梯度的凸包判别 图 26.16提示了判别方法。把各梯度当作点，看它们的凸包（convex hull）

$$\operatorname{conv}\{\boldsymbol{g}_1, \dots, \boldsymbol{g}_m\} = \Big\{ \sum_{i=1}^{m} \theta_i \boldsymbol{g}_i \,:\, \theta \in \Delta_m \Big\},$$

也就是全部梯度的加权平均组成的集合。下面的引理说，这个集合是否包含原点，恰好决定共同下降方向是否存在。

引理 26.8　共同下降方向的存在性　存在满足式 (26.19)的 $\boldsymbol{d}$，当且仅当 $\mathbf{0} \notin \operatorname{conv}\{\boldsymbol{g}_1, \dots, \boldsymbol{g}_m\}$。

证明　先设 $\mathbf{0}$ 在凸包中，即有 $\theta \in \Delta_m$ 使 $\sum_i \theta_i \boldsymbol{g}_i = \mathbf{0}$。若式 (26.19)成立，把它们按 $\theta_i \geq 0$ 加权相加，由于至少有一个 $\theta_i > 0$，得到

$$0 = \left\langle \sum_i \theta_i \boldsymbol{g}_i, \boldsymbol{d} \right\rangle = \sum_i \theta_i \langle \boldsymbol{g}_i, \boldsymbol{d} \rangle < 0,$$

矛盾。

再设 $\mathbf{0}$ 不在凸包中。凸包是非空紧凸集，记原点在它上面的投影为 $\bar{\boldsymbol{g}} \neq \mathbf{0}$。第 11章的投影性质给出，对凸包中任一点 $\boldsymbol{v}$，

$$\langle \mathbf{0} - \bar{\boldsymbol{g}}, \boldsymbol{v} - \bar{\boldsymbol{g}} \rangle \leq 0.$$

取 $\boldsymbol{v} = \boldsymbol{g}_i$，整理得

$$\langle \boldsymbol{g}_i, \bar{\boldsymbol{g}} \rangle \geq \|\bar{\boldsymbol{g}}\|_2^2 > 0.$$

令 $\boldsymbol{d} = -\bar{\boldsymbol{g}}$，式 (26.19)成立。 ■

第二部分的构造不只是存在性证明，第 26.4节就要把它变成算法。原点在凸包中的情形有专门的名称。

定义 26.9　Pareto 驻定　若存在 $\theta \in \Delta_m$，使

$$\sum_{i=1}^{m} \theta_i \nabla f_i(\boldsymbol{x}) = \mathbf{0}, \tag{26.20}$$

称 $\boldsymbol{x}$ 为Pareto 驻定（Pareto stationary）点。

$m = 1$ 时，$\theta_1 = 1$，式 (26.20)就是 $\nabla f_1 = \mathbf{0}$，回到单目标的驻定点。多目标时，并不要求每个梯度为零，只要求它们能以非负系数相互抵消。

必要性与连续例　局部最优点不允许共同下降，由此得到一阶必要条件。

定理 26.10　Pareto 驻定的必要性　设 $\boldsymbol{x}$ 是 $\boldsymbol{C}$ 的内点，各 f_i 在 $\boldsymbol{x}$ 处可微。若 $\boldsymbol{x}$ 是局部弱 Pareto 最优点，特别地若 $\boldsymbol{x}$ 是局部 Pareto 最优点，则 $\boldsymbol{x}$ 是 Pareto 驻定点。

证明 若 $\boldsymbol{x}$ 不是 Pareto 驻定点，由引理 26.8，存在满足式 (26.19)的 $\boldsymbol{d}$。对充分小的 $t>0$，由 Taylor 展开，

$$f_i(\boldsymbol{x}+t\boldsymbol{d}) = f_i(\boldsymbol{x}) + t\langle \boldsymbol{g}_i, \boldsymbol{d}\rangle + o(t) < f_i(\boldsymbol{x})$$

对所有 i 成立。$\boldsymbol{x}$ 是内点，$\boldsymbol{x}+t\boldsymbol{d}$ 可行，这与局部弱 Pareto 最优矛盾。 ■

下面在例 (26.4)上检查，见图 26.17。此时 $\boldsymbol{g}_1 = \boldsymbol{x}-\boldsymbol{a}$，$\boldsymbol{g}_2 = \boldsymbol{x}-\boldsymbol{b}$。在线段外的点 $\boldsymbol{p}=(1,1)$ 处，

$$\boldsymbol{g}_1 = (0,1), \qquad \boldsymbol{g}_2 = (1,0).$$

它们的凸组合是 $(1-\theta,\theta)$，永远不为零，所以 $\boldsymbol{p}$ 不是驻定点。取 $\theta=1/2$ 得最短的组合 $(1/2,1/2)$，方向 $\boldsymbol{d}=(-1/2,-1/2)$ 使两个目标同时下降。

在线段上的点 $\boldsymbol{q}=(0.6,0.4)$ 处，

$$\boldsymbol{g}_1 = (-0.4,0.4), \qquad \boldsymbol{g}_2 = (0.6,-0.6).$$

两个梯度方向相反，取 $\theta=(0.6,0.4)$ 得到 $0.6\boldsymbol{g}_1 + 0.4\boldsymbol{g}_2 = \boldsymbol{0}$，$\boldsymbol{q}$ 是驻定点。这里的 $\theta_1 = 0.6$ 恰好等于式 (26.11)中选中 $\boldsymbol{q}$ 的权重 w。

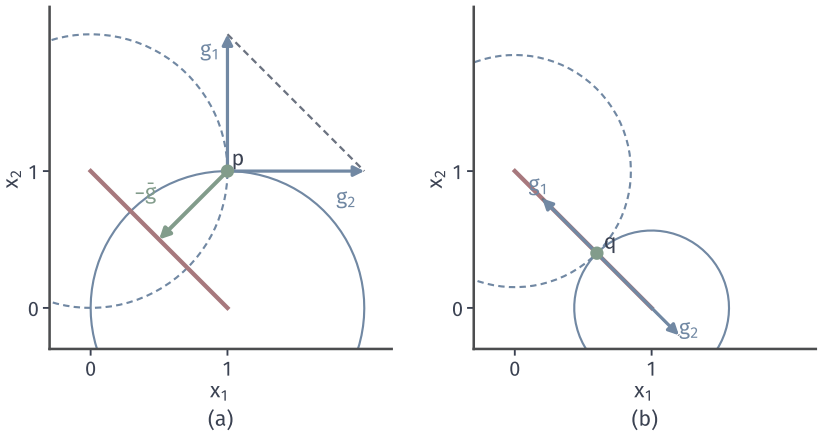


图 26.17 例 (26.4)中两点处的梯度，圆是经过该点的两条等高线，红色线段是 Pareto 解集。(a) 线段外的点 $\boldsymbol{p}=(1,1)$，两个梯度的凸包（虚线）不含零，绿色箭头是最小范数组合的反方向。(b) 线段上的点 $\boldsymbol{q}=(0.6,0.4)$，两个梯度反向，凸包含零，两条等高线在 $\boldsymbol{q}$ 相切。

图 26.17(b) 还显示了一件事：在 $\boldsymbol{q}$ 处两个圆相切，要进入一个圆的内部，就必须走出另一个圆。这是取舍的局部形象。

驻定点不一定是 Pareto 最优点 定理 26.10只有一个方向。Pareto 驻定只排除严格的共同下降，并不排除“有的目标不变，另一些目标下降”。取 $\boldsymbol{x} \in \mathbb{R}^2$，

$$f_1(\boldsymbol{x}) = x_1^2, \qquad f_2(\boldsymbol{x}) = x_2. \tag{26.21}$$

在原点，$\boldsymbol{g}_1 = \mathbf{0}$，$\boldsymbol{g}_2 = (0,1)$，取 $\theta = (1,0)$，式 (26.20)成立。可是沿 $(0,-t)$ 移动，f_1 保持为 0，f_2 严格下降，原点被支配，见图 26.18(a)。

问题还可能更严重。取一元函数 $f_1(x) = f_2(x) = -x^2$，$x = 0$ 是 Pareto 驻定点，但 $x = \pm 1$ 处两个目标都更小，原点连弱 Pareto 最优点都不是，见图 26.18(b)。这与单目标的极大点也是驻定点是同一回事。

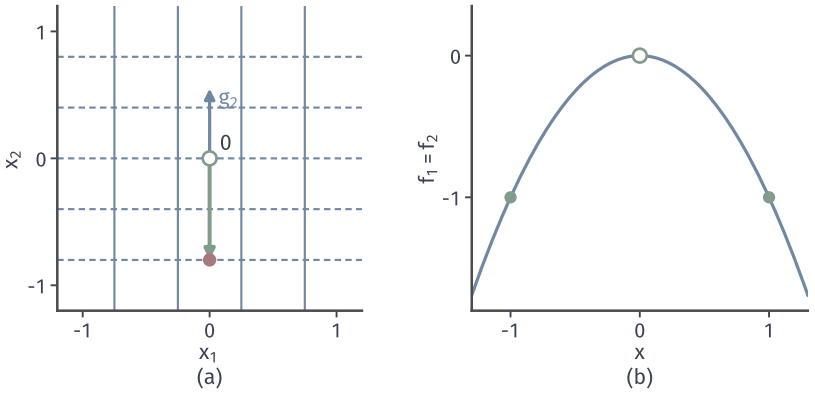


图 26.18 Pareto 驻定不足以断定最优。(a) 式 (26.21)，竖线是 f_1 的等高线，虚线是 f_2 的等高线；在空心点（原点）处 $\boldsymbol{g}_1 = \mathbf{0}$，沿绿色箭头 f_1 不变、f_2 下降，红点支配原点。(b)$f_1 = f_2 = -x^2$，空心点是驻定点，两个绿点的目标都更小。

凸问题中的充分性 要从驻定走到最优，需要凸性。此时式 (26.20)的系数 θ 恰好提供了一组权重。

定理 26.11 凸问题的驻定点 设 $\boldsymbol{C} = \mathbb{R}^n$，各 f_i 凸且可微，$\boldsymbol{x}$ 满足式 (26.20)。则 $\boldsymbol{x}$ 是 $\sum_i \theta_i f_i$ 的全局最小点，因而是全局弱 Pareto 最优点；若所有 $\theta_i > 0$，$\boldsymbol{x}$ 是全局 Pareto 最优点。

证明 $\sum_i \theta_i f_i$ 是凸函数，其梯度在 $\boldsymbol{x}$ 处为零，由第 1章的一阶条件，$\boldsymbol{x}$ 是它的全局最小点。再由定理 26.3得结论。 ■

式 (26.21)的原点符合定理的条件，但 $\theta_2 = 0$，所以只能得到弱 Pareto 最优，这正好和前面看到的现象一致。在例 (26.4)的线段内部，θ 的两个分量都为正，得到的是 Pareto 最优。

26.1 多目标问题
26.2 标量化
26.3 最优解的判别
26.3.1 共同下降方向
26.3.2 可行方向
26.4 多梯度下降
26.5 前沿的计算
26.6 前沿的评价
26.7 本章小结

26.3.2 可行方向

候选点若在可行集边界上，只有一部分方向走得动，梯度的凸包不含零也不等于存在可行的共同下降方向。这一小节把判别限制在可行方向上，并调用第 17章的约束条件。

问题与记号 由于 m 已经用来表示目标个数，约束的下标改写为

$$\boldsymbol{C}=\{\boldsymbol{x}:\ g_j(\boldsymbol{x})\le 0,\ j=1,\dots,q,\ \ h_k(\boldsymbol{x})=0,\ k=1,\dots,p\}.$$

活动集 $A(\bar{\boldsymbol{x}})$、切锥 $\boldsymbol{T}_{\boldsymbol{C}}(\bar{\boldsymbol{x}})$、线性化锥、LICQ、MFCQ 的含义都与第 17章相同，只是把不等式的下标换成了 j，等式的下标换成了 k。这里的 g_j 是约束函数，加粗的 $\boldsymbol{g}_i$ 才是目标的梯度。

切锥上的必要条件 “能走的方向”由切锥描述，一阶必要条件的形式与单目标的切锥条件相同。

定理 26.12 切锥上的必要条件 设 $\bar{\boldsymbol{x}}$ 是局部弱 Pareto 最优点，各 f_i 在 $\bar{\boldsymbol{x}}$ 处可微。则不存在 $\boldsymbol{d}\in\boldsymbol{T}_{\boldsymbol{C}}(\bar{\boldsymbol{x}})$，使

$$\langle\nabla f_i(\bar{\boldsymbol{x}}),\boldsymbol{d}\rangle<0\quad\text{对所有 } i=1,\dots,m. \tag{26.22}$$

证明 设这样的 $\boldsymbol{d}$ 存在。由切锥定义，有可行点列 $\boldsymbol{x}^{(k)}\to\bar{\boldsymbol{x}}$ 与 $t_k\downarrow 0$，使 $(\boldsymbol{x}^{(k)}-\bar{\boldsymbol{x}})/t_k\to\boldsymbol{d}$。Taylor 展开并除以 t_k，

$$\frac{f_i(\boldsymbol{x}^{(k)})-f_i(\bar{\boldsymbol{x}})}{t_k}\to\langle\nabla f_i(\bar{\boldsymbol{x}}),\boldsymbol{d}\rangle<0.$$

目标个数有限，所以 k 足够大时，所有 $f_i(\boldsymbol{x}^{(k)})<f_i(\bar{\boldsymbol{x}})$ 同时成立，与局部弱 Pareto 最优矛盾。 ■

目标权重与约束乘子 切锥不容易计算。约束资格把它换成线性化锥，结论就可以用乘子写出来，形式上是把 KKT 条件中目标的梯度换成目标梯度的凸组合。

证明不用重新做 Farkas 那一套，把问题改写成单目标问题即可：引入一个变量 t 代表“所有目标相对当前点的最大变化”，然后要求这个变化不能为负。

定理 26.13　多目标 KKT 必要条件　设 f_i、g_j、h_k 在局部弱 Pareto 最优点 $\bar{\boldsymbol{x}}$ 附近连续可微，并且 $\bar{\boldsymbol{x}}$ 满足 MFCQ。则存在 $\boldsymbol{\theta} \in \Delta_m$，$\boldsymbol{\lambda} \geq \mathbf{0}$，$\boldsymbol{\nu}$，使

$$\sum_{i=1}^{m} \theta_i \nabla f_i(\bar{\boldsymbol{x}}) + \sum_{j=1}^{q} \lambda_j \nabla g_j(\bar{\boldsymbol{x}}) + \sum_{k=1}^{p} \nu_k \nabla h_k(\bar{\boldsymbol{x}}) = \mathbf{0}, \tag{26.23}$$

并且 $\lambda_j g_j(\bar{\boldsymbol{x}}) = 0$ 对所有 j 成立。

证明　考虑变量为 $(\boldsymbol{x}, t)$ 的单目标问题

$$\min_{\boldsymbol{x},t} \; t \quad \text{s.t.} \quad f_i(\boldsymbol{x}) - f_i(\bar{\boldsymbol{x}}) - t \leq 0, \;\; \boldsymbol{x} \in \boldsymbol{C}.$$

先说明 $(\bar{\boldsymbol{x}}, 0)$ 是它的局部最小点。若 $\boldsymbol{x}$ 靠近 $\bar{\boldsymbol{x}}$，$(\boldsymbol{x}, t)$ 可行且 $t < 0$，则 $f_i(\boldsymbol{x}) < f_i(\bar{\boldsymbol{x}})$ 对所有 i 成立，与局部弱 Pareto 最优矛盾。

再说明 MFCQ 在 $(\bar{\boldsymbol{x}}, 0)$ 处成立。设 $\bar{\boldsymbol{d}}$ 是原约束的 MFCQ 方向。增广问题中等式约束的梯度是 $(\nabla h_k, 0)$，线性无关；取方向 $(\bar{\boldsymbol{d}}, \sigma)$，$\sigma$ 足够大，则

$$\langle \nabla f_i(\bar{\boldsymbol{x}}), \bar{\boldsymbol{d}} \rangle - \sigma < 0 \quad \text{对所有 } i,$$

其余条件与原约束相同。

由第 17章的 KKT 必要性定理，存在乘子 $\boldsymbol{\theta} \geq \mathbf{0}$（对应 $f_i - f_i(\bar{\boldsymbol{x}}) - t \leq 0$）、$\boldsymbol{\lambda} \geq \mathbf{0}$ 与 $\boldsymbol{\nu}$。对 t 的驻定条件是 $1 - \sum_i \theta_i = 0$，所以 $\boldsymbol{\theta} \in \Delta_m$；对 $\boldsymbol{x}$ 的驻定条件是式 (26.23)；互补条件来自原约束的互补松弛。 ■

约束资格不能省。取一元变量，$f_1(x) = f_2(x) = x$，约束 $g(x) = x^2 \leq 0$。可行集只有 $\{0\}$，所以 0 是 Pareto 最优点。但 $\nabla f_1 = \nabla f_2 = 1$，$\nabla g(0) = 0$，式 (26.23)左边恒等于 1。这里 MFCQ 失败，因为 $\langle \nabla g(0), d \rangle = 0$，不可能严格小于零。

凸问题中的充分性　和无约束情形一样，充分性需要凸性，而且权重的符号决定结论的强弱。

定理 26.14　凸问题的多目标 KKT 充分性　设 $\boldsymbol{D}$ 是包含 $\boldsymbol{C}$ 的开凸集，f_i、g_j 在 $\boldsymbol{D}$ 上凸且可微，h_k 仿射。若可行点 $\bar{\boldsymbol{x}}$ 满足式 (26.23)，$\boldsymbol{\theta} \in \Delta_m$，$\boldsymbol{\lambda} \geq \mathbf{0}$，且互补松弛成立，则 $\bar{\boldsymbol{x}}$ 是 $\sum_i \theta_i f_i$ 在 $\boldsymbol{C}$ 上的全局最小点，因而是全局弱 Pareto 最优点；若所有 $\theta_i > 0$，$\bar{\boldsymbol{x}}$ 是全局 Pareto 最优点。

证明 式 (26.23)与互补松弛正是凸问题 $\min_{\boldsymbol{c}} \sum_i \theta_i f_i$ 的 KKT 条件。由第 17章的凸问题 KKT 充分性，$\bar{\boldsymbol{x}}$ 是全局最小点。再由定理 26.3得结论。 ■

这里没有要求约束资格，这与单目标的凸问题相同。必要性要约束资格而不要凸性，充分性要凸性而不要约束资格，两个方向的条件不能互换。

例：无约束判据为什么失效 在例 (26.4)上加一个约束 $g(\boldsymbol{x}) = x_1 + x_2 - 1/2 \le 0$。原来的解集 $x_1 + x_2 = 1$ 整条被挡在可行集外面，新的候选应该在边界上。取 $\bar{\boldsymbol{x}} = (1/4, 1/4)$，

$$\boldsymbol{g}_1 = \bar{\boldsymbol{x}} - \boldsymbol{a} = (-3/4, 1/4), \qquad \boldsymbol{g}_2 = \bar{\boldsymbol{x}} - \boldsymbol{b} = (1/4, -3/4).$$

这两个梯度的凸包不含零。取 $\theta = (1/2, 1/2)$ 得到其中最短的组合

$$\bar{\boldsymbol{g}} = (-1/4, -1/4).$$

如果套用无约束判据，就会以为 $\bar{\boldsymbol{x}}$ 不是驻定点。可是下降方向 $-\bar{\boldsymbol{g}} = (1/4, 1/4)$ 走出了可行集，这一步根本走不了。

加上约束的乘子就对了。由式 (26.23)，$\nabla g = (1, 1)$，

$$\tfrac{1}{2}\boldsymbol{g}_1 + \tfrac{1}{2}\boldsymbol{g}_2 + \lambda(1, 1) = \boldsymbol{0},$$

解得 $\lambda = 1/4 \ge 0$。$\bar{\boldsymbol{x}}$ 在边界上，互补松弛成立，问题是凸的，权重全正，由定理 26.14，$\bar{\boldsymbol{x}}$ 是全局 Pareto 最优点。

更一般地，式 (26.23)对可行点 $\boldsymbol{x}$ 写出来是 $\boldsymbol{x} = (\theta - \lambda, 1 - \theta - \lambda)$，其中 $\theta = (\theta, 1 - \theta)$。边界条件 $x_1 + x_2 = 1/2$ 给出 $\lambda = 1/4$，所以约束问题的驻定点是

$$\boldsymbol{x} = \big(\theta - \tfrac{1}{4},\ \tfrac{3}{4} - \theta\big), \qquad 0 \le \theta \le 1. \tag{26.24}$$

代入目标，前沿是 $\big((1-\theta)^2 + \tfrac{1}{16},\ \theta^2 + \tfrac{1}{16}\big)$，恰是原前沿沿两个方向平移 $1/16$。图 26.19把解集和前沿画了出来。

26.1 多目标问题
26.2 标量化
26.3 最优解的判别
26.4 多梯度下降
26.4.1 最小范数组合
26.4.2 共同步长
26.5 前沿的计算
26.6 前沿的评价
26.7 本章小结

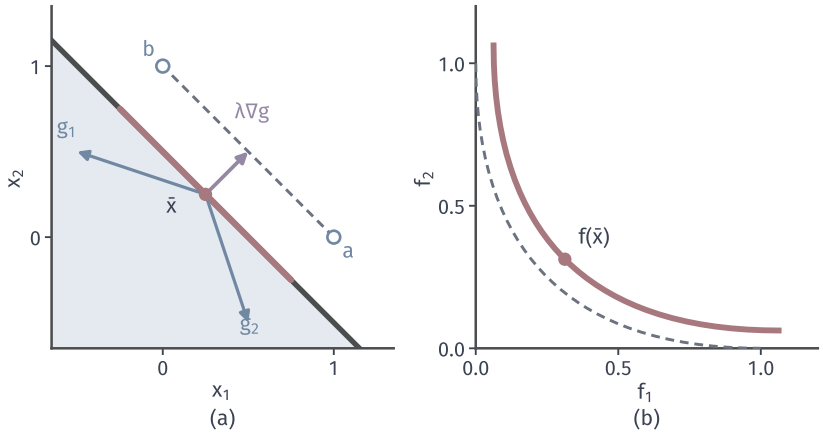


图 26.19 加上半平面约束 $x_1 + x_2 \le 1/2$ 后的例子。(a) 深灰粗线是活动约束，红色线段是约束下的解集（式 (26.24)），虚线是原来的解集；在 $\bar{\boldsymbol{x}} = (1/4, 1/4)$ 处，$\boldsymbol{g}_1, \boldsymbol{g}_2$ 的中点被紫色的 $\lambda\nabla g$ 抵消。(b) 红色曲线是约束下的前沿，虚线是原前沿，红点是 $\boldsymbol{f}(\bar{\boldsymbol{x}}) = (5/16, 5/16)$。

端点 $\theta = 0, 1$ 的权重有零，但此时分别是 f_2、f_1 在可行集上的唯一最小点，由定理 26.3的第 3 条仍是 Pareto 最优点。这说明定理 26.14中“全正”只是充分条件，端点要单独检查。

26.4 多梯度下降

第 26.3.1节的判别给出了一个方向：梯度凸包中离原点最近的点。这一节把它变成迭代。问题是：怎样在几个目标的梯度之间取折中，才能保证一步之后每个目标都不变差？

由此得到的方法称为**多梯度下降算法**（multiple-gradient descent algorithm，MGDA）。它不需要事先给定偏好，权重是每一步按当前的几何现算的，这一点和固定加权和不同。

26.4.1 最小范数组合

主要思想 最简单的想法是把各目标的梯度平均一下，然后沿反方向走。看一个具体的数据：

$$\boldsymbol{g}_1 = (10, 1), \qquad \boldsymbol{g}_2 = (-1, 1).$$

平均后得 $(4.5, 1)$，方向是 $\boldsymbol{d} = (-4.5, -1)$。检查第二个目标的方向导数：

$$\langle \boldsymbol{g}_2, \boldsymbol{d} \rangle = 4.5 - 1 = 3.5 > 0.$$

f_2 反而上升。梯度长度悬殊时，长的那个梯度支配了平均，短的那个目标被牺牲了。

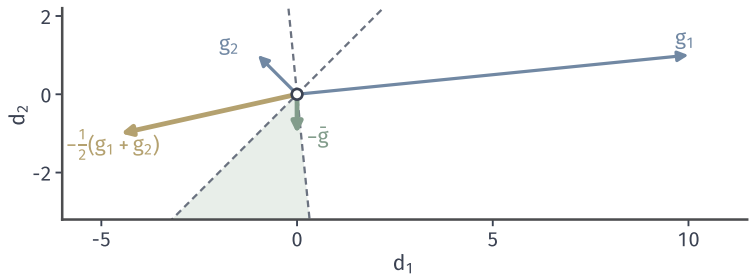


图 26.20　平均方向与最小范数方向，$\boldsymbol{g}_1 = (10, 1)$，$\boldsymbol{g}_2 = (-1, 1)$。两条灰色虚线分别垂直于两个梯度，浅绿楔形是共同下降方向。黄色箭头是平均梯度的反方向，落在楔形外；绿色箭头是 $-\bar{\boldsymbol{g}} = (0, -1)$，落在楔形内。

要保证每个目标都下降，应当转而问：在所有梯度的加权平均中，哪一个最短？记

$$\theta^\star \in \arg\min_{\theta \in \Delta_m} \frac{1}{2}\Big\|\sum_{i=1}^{m} \theta_i \boldsymbol{g}_i\Big\|_2^2, \qquad \bar{\boldsymbol{g}} = \sum_{i=1}^{m} \theta_i^\star \boldsymbol{g}_i, \tag{26.25}$$

并取方向 $\boldsymbol{d} = -\bar{\boldsymbol{g}}$。式 (26.25)的权重子问题在单纯形上最小化一个凸二次函数。$\bar{\boldsymbol{g}}$ 是原点在凸包上的投影，所以唯一，而 $\theta^\star$ 不一定唯一。

在上面的数据上，后面的式 (26.27)给出 $\theta_1^\star = 1/11$，于是 $\bar{\boldsymbol{g}} = (0, 1)$，方向 $(0, -1)$ 落在共同下降的楔形内，见图 26.20。两个方向导数都等于 -1。

引理 26.15　最小范数组合的下降性质　对式 (26.25)定义的 $\bar{\boldsymbol{g}}$，

$$\langle \boldsymbol{g}_i, -\bar{\boldsymbol{g}} \rangle \le -\|\bar{\boldsymbol{g}}\|_2^2 \quad \text{对所有 } i = 1, \dots, m. \tag{26.26}$$

并且 $\bar{\boldsymbol{g}} = \boldsymbol{0}$ 当且仅当 $\boldsymbol{x}$ 是无约束的 Pareto 驻定点。

证明　不等式已在引理 26.8的证明中得到，投影性质给出

$$\langle \boldsymbol{g}_i, \bar{\boldsymbol{g}} \rangle \ge \|\bar{\boldsymbol{g}}\|_2^2,$$

这对 $\bar{\boldsymbol{g}} = \boldsymbol{0}$ 也成立。第二句是 Pareto 驻定的定义：$\boldsymbol{0}$ 在凸包中，当且仅当它到凸包的最短距离为零。 ∎

式 (26.26)是整个方法的关键：只要 $\bar{\boldsymbol{g}} \neq \boldsymbol{0}$，每个目标的方向导数都不大于 $-\|\bar{\boldsymbol{g}}\|_2^2$，都确实在下降，而且下降速度有统一的下界。

两个目标的闭式解 $m=2$ 时，令 $\theta=(\theta,1-\theta)$，$\boldsymbol{g}_1\neq\boldsymbol{g}_2$。子问题是一元二次函数：

$$\phi(\theta)=\|\theta\boldsymbol{g}_1+(1-\theta)\boldsymbol{g}_2\|_2^2=\|\boldsymbol{g}_2+\theta(\boldsymbol{g}_1-\boldsymbol{g}_2)\|_2^2.$$

求导令其为零，得到无约束的最小点 $\langle\boldsymbol{g}_2,\boldsymbol{g}_2-\boldsymbol{g}_1\rangle/\|\boldsymbol{g}_1-\boldsymbol{g}_2\|_2^2$。把它截断到 $[0,1]$，由于 ϕ 是凸的一元二次函数，截断后仍是区间上的最小点：

$$\theta^\star=\min\Big\{1,\ \max\Big\{0,\ \frac{\langle\boldsymbol{g}_2,\boldsymbol{g}_2-\boldsymbol{g}_1\rangle}{\|\boldsymbol{g}_1-\boldsymbol{g}_2\|_2^2}\Big\}\Big\}. \tag{26.27}$$

若 $\boldsymbol{g}_1=\boldsymbol{g}_2$，任取 θ 都得到同一个 $\bar{\boldsymbol{g}}$。

图 26.21是三种情形。(a) 垂足落在线段内部，$0<\theta^\star<1$，此时式 (26.26)对两个目标都取等号，两个目标下降速度相同。(b) 垂足落在线段之外，截断后 $\bar{\boldsymbol{g}}$ 就是较短的梯度，方向只对那一个目标是最陡的，另一个目标下降得更快。(c) 原点在线段上，$\bar{\boldsymbol{g}}=\mathbf{0}$，停止。

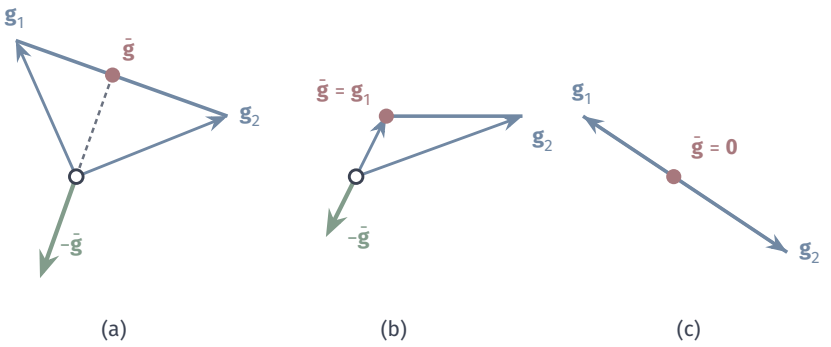


图 26.21 两个梯度的最小范数组合。蓝色线段是凸包，红点是 $\bar{\boldsymbol{g}}$，绿色箭头是 $-\bar{\boldsymbol{g}}$，空心点是原点。(a) 垂足在线段内部。(b) 垂足在线段外，截断到较短的梯度 $\boldsymbol{g}_1$。(c) 原点在线段上，点是 Pareto 驻定的，没有更新方向。

方向的最优性 最小范数这个构造还可以从另一面看：它正好是一个“保最差目标”的方向问题的解。假设只看一阶模型，希望下降最少的目标也尽量下降，同时用 $\frac{1}{2}\|\boldsymbol{d}\|_2^2$ 防止步子过大。

定理 26.16 最坏目标的最陡方向 问题

$$\min_{\boldsymbol{d}\in\mathbb{R}^n}\ \max_{1\le i\le m}\langle\boldsymbol{g}_i,\boldsymbol{d}\rangle+\frac{1}{2}\|\boldsymbol{d}\|_2^2 \tag{26.28}$$

的唯一解是 $\boldsymbol{d}=-\bar{\boldsymbol{g}}$，最优值是 $-\frac{1}{2}\|\bar{\boldsymbol{g}}\|_2^2$。

26.1 多目标问题
26.2 标量化
26.3 最优解的判别
26.4 多梯度下降
26.4.1 最小范数组合
26.4.2 共同步长
26.5 前沿的计算
26.6 前沿的评价
26.7 本章小结

证明 目标是凸函数加强凸函数，解唯一。对任意 $\boldsymbol{d}$，最大值不小于凸组合，所以

$$\max_i \langle \boldsymbol{g}_i, \boldsymbol{d}\rangle + \tfrac{1}{2}\|\boldsymbol{d}\|_2^2 \geq \langle \bar{\boldsymbol{g}}, \boldsymbol{d}\rangle + \tfrac{1}{2}\|\boldsymbol{d}\|_2^2.$$

右端关于 $\boldsymbol{d}$ 的最小值在 $\boldsymbol{d} = -\bar{\boldsymbol{g}}$ 取到，所以

$$\max_i \langle \boldsymbol{g}_i, \boldsymbol{d}\rangle + \tfrac{1}{2}\|\boldsymbol{d}\|_2^2 \geq -\tfrac{1}{2}\|\bar{\boldsymbol{g}}\|_2^2.$$

反过来，取 $\boldsymbol{d} = -\bar{\boldsymbol{g}}$，由式 (26.26)，最大值不超过 $-\|\bar{\boldsymbol{g}}\|_2^2$，目标不超过 $-\frac{1}{2}\|\bar{\boldsymbol{g}}\|_2^2$。两边合起来取等，$-\bar{\boldsymbol{g}}$ 是解。 ■

权重的含义 $\theta^\star$ 看起来也是一组权重，但它与加权和的权重 $\boldsymbol{w}$ 职责不同，见表 26.2。$\boldsymbol{w}$ 是决策者给定的，整个求解过程中不变，表达的是偏好。$\theta^\star$ 是算法每一步根据当前梯度算出来的，表达的是当前的几何。

表 26.2 固定加权与多梯度下降中的权重。

	加权和的 $\boldsymbol{w}$	多梯度下降的 $\theta^\star$
来源	使用者事先给定	每步由梯度算出
迭代中	固定	随 $\boldsymbol{x}$ 变化
单个目标	可能上升	不上升（配合步长）
终点	该偏好下的解	取决于起点的一个驻定点

要注意 $\theta^\star$ 不是尺度无关的。把上面的 f_1 除以 10，$\boldsymbol{g}_1$ 变成 $(1, 0.1)$，由式 (26.27)算得 $\theta^\star \approx 0.603$，$\bar{\boldsymbol{g}} \approx (0.206, 0.457)$，方向和原来的 $(0, 1)$ 不同。所以第 26.1.3节的提醒在这里同样适用：梯度长度悬殊的问题，先要说明目标的尺度。

$m > 2$ 时，令 $\boldsymbol{G}$ 是 $m \times m$ 矩阵，元素为 $\boldsymbol{G}_{i,j} = \langle \boldsymbol{g}_i, \boldsymbol{g}_j\rangle$，子问题就是在单纯形上最小化 $\frac{1}{2}\theta^\top \boldsymbol{G}\theta$。第 20章的二次规划方法和第 21章的 Frank–Wolfe 方法都能解它。单纯形的规模只有 m，主要开销在于计算 m 个梯度和 $\boldsymbol{G}$ 的 $O(m^2 n)$ 次运算。

26.4.2 共同步长

有了方向，还要决定走多远。若沿各自的梯度分别走一步，再把得到的位置取平均，效果等同于沿平均梯度走一步，前面已经看到这可能让某个目标上升。所以这一小节要为所有目标选一个共同的步长，并检查每一个目标的下降。

多目标的充分下降　把单目标的回溯规则（第 5章）推广：一个步长 $\alpha>0$ 只有在所有目标都达到下面的下降量时才被接受，

$$f_i(\boldsymbol{x}-\alpha\bar{\boldsymbol{g}})\le f_i(\boldsymbol{x})-c\,\alpha\|\bar{\boldsymbol{g}}\|_2^2 \quad \text{对所有 } i, \tag{26.29}$$

其中 $c\in(0,1)$，常取 $c=1/2$。回溯时从 $\alpha=1$ 开始，不满足就乘以 $\beta\in(0,1)$，这里取 $\beta=1/2$。

为什么步长一定找得到？设每个 ∇f_i 是 L_i-Lipschitz 的，记 $L_{\max}=\max_i L_i$。由下降引理（第 5章）和式 (26.26)，

$$f_i(\boldsymbol{x}-\alpha\bar{\boldsymbol{g}})\le f_i(\boldsymbol{x})+\alpha\langle \boldsymbol{g}_i,-\bar{\boldsymbol{g}}\rangle+\frac{L_i\alpha^2}{2}\|\bar{\boldsymbol{g}}\|_2^2\le f_i(\boldsymbol{x})-\alpha\Big(1-\frac{L_i\alpha}{2}\Big)\|\bar{\boldsymbol{g}}\|_2^2.$$

所以当 $\alpha\le 1/L_{\max}$ 时，括号不小于 $1/2$，式 (26.29)在 $c=1/2$ 时成立。

从这里也看得出共同步长的代价：步长受曲率最大的那个目标限制，$L_{\max}$ 很大时所有目标都得小步前进。

计算过程　下面在一个病态的例子上走三轮。目标的第一项是第 5章贯穿使用的二次函数，第二项把点拉向 $(4,3)$：

$$f_1(\boldsymbol{x})=\frac{1}{2}(x_1^2+9x_2^2),\qquad f_2(\boldsymbol{x})=\frac{1}{2}\big[(x_1-4)^2+(x_2-3)^2\big]. \tag{26.30}$$

变量

- 迭代点 $\boldsymbol{x}^{(t)}\in\mathbb{R}^n$，各目标的值 $f_i(\boldsymbol{x}^{(t)})$；
- 梯度 $\boldsymbol{g}_i^{(t)}=\nabla f_i(\boldsymbol{x}^{(t)})$，$i=1,\dots,m$；
- 组合系数 $\theta^{(t)}\in\Delta_m$，组合梯度 $\bar{\boldsymbol{g}}^{(t)}$；
- 步长 $\alpha^{(t)}$，常数 c、β，容差 ϵ。

初始化　给定起点 $\boldsymbol{x}^{(0)}$ 和容差 ϵ。例中取 $\boldsymbol{x}^{(0)}=(1,1)$，$c=\beta=1/2$，此时目标值为

$$\boldsymbol{f}(\boldsymbol{x}^{(0)})=(5,\ 6.5).$$

每轮更新　对 $t=0,1,\dots$ 重复下列步骤，直到 $\|\bar{\boldsymbol{g}}^{(t)}\|_2\le\epsilon$。

1. 计算各目标的梯度。例中第一轮

$$\boldsymbol{g}_1^{(0)}=(1,9),\qquad \boldsymbol{g}_2^{(0)}=(-3,-2).$$

2. 由式 (26.25)求 $\theta^{(t)}$ 与 $\bar{\boldsymbol{g}}^{(t)}$，两个目标时用式 (26.27)。例中第一轮

$$\theta^{(0)} = \frac{34}{137} \approx 0.2482, \qquad \bar{\boldsymbol{g}}^{(0)} \approx (-2.0073,\ 0.7299),$$

并且 $\|\bar{\boldsymbol{g}}^{(0)}\|_2^2 \approx 4.5620$。

3. 回溯求步长：从 $\alpha = 1$ 开始，检查式 (26.29)是否对每一个目标成立。例中 $\alpha = 1$ 的试探点是 $(3.0073, 0.2701)$，$f_1 \approx 4.8501$，而要求不超过 $5 - \frac{1}{2} \times 4.5620 \approx 2.7190$，被拒绝。$\alpha = 1/2$ 的试探点满足两个目标的要求：

$$f_1 \approx 3.8220 \le 3.8595, \qquad f_2 \approx 4.7892 \le 5.3595.$$

4. 沿 $-\bar{\boldsymbol{g}}^{(t)}$ 走一步，更新为

$$\boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} - \alpha^{(t)} \bar{\boldsymbol{g}}^{(t)}. \tag{26.31}$$

例中第一轮

$$\boldsymbol{x}^{(1)} \approx (2.0036,\ 0.6350), \qquad \boldsymbol{f}(\boldsymbol{x}^{(1)}) \approx (3.8220,\ 4.7892).$$

第二轮的梯度是

$$\boldsymbol{g}_1^{(1)} \approx (2.0036,\ 5.7153), \qquad \boldsymbol{g}_2^{(1)} \approx (-1.9964,\ -2.3650).$$

由此算得

$$\theta^{(1)} \approx 0.3333, \quad \bar{\boldsymbol{g}}^{(1)} \approx (-0.6631,\ 0.3283), \quad \|\bar{\boldsymbol{g}}^{(1)}\|_2^2 \approx 0.5475.$$

$\alpha = 1$ 和 $\alpha = 1/2$ 都因 f_1 不满足式 (26.29)被拒绝，$\alpha = 1/4$ 被接受，得到

$$\boldsymbol{x}^{(2)} \approx (2.1694,\ 0.5530), \qquad \boldsymbol{f}(\boldsymbol{x}^{(2)}) \approx (3.7292,\ 4.6695).$$

第三轮的梯度是

$$\boldsymbol{g}_1^{(2)} \approx (2.1694,\ 4.9767), \qquad \boldsymbol{g}_2^{(2)} \approx (-1.8306,\ -2.4470).$$

算得

$$\theta^{(2)} \approx 0.3584, \quad \bar{\boldsymbol{g}}^{(2)} \approx (-0.3969,\ 0.2138), \quad \|\bar{\boldsymbol{g}}^{(2)}\|_2^2 \approx 0.2032.$$

同样 $\alpha = 1/4$ 被接受，

$$\boldsymbol{x}^{(3)} \approx (2.2687,\ 0.4995), \qquad \boldsymbol{f}(\boldsymbol{x}^{(3)}) \approx (3.6962,\ 4.6250).$$

可以看到，两个目标每一轮都严格下降，$\theta^{(t)}$ 在逐轮变化。

最终得到 $\boldsymbol{x}^\star \approx (2.3933, 0.4260)$，目标值约为 $(3.6808, 4.6034)$，$\bar{\boldsymbol{g}}$ 的范数已到舍入误差量级。这一点的 $\theta^\star \approx 0.4017$，用它作权重，第 26.2.1节的加权和在这一点取到最优。

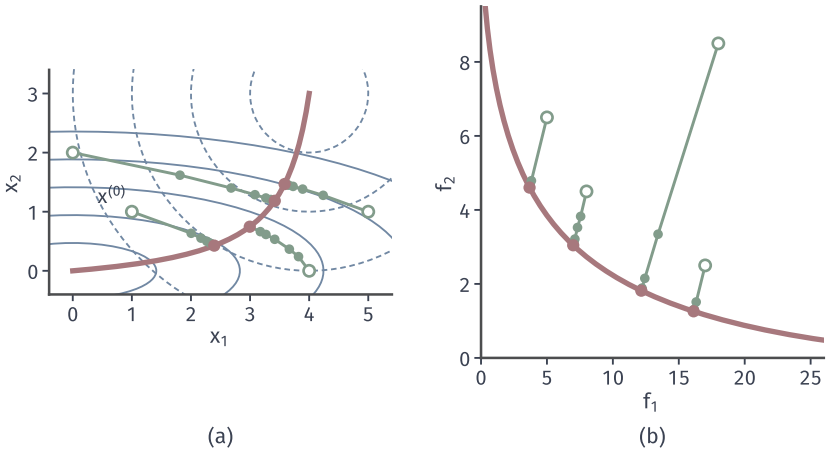


图 26.22 多梯度下降在例 (26.30)上的路径。(a) 决策平面，实线与虚线分别是 f_1, f_2 的等高线，红色曲线是 Pareto 解集，绿线是四个起点（空心点）的路径，小点是前五步，红点是终点。(b) 同一批路径在目标平面上的像，红色曲线是 Pareto 前沿。不同起点落到前沿的不同位置。

收敛性 图 26.22显示，路径都在目标平面上朝左下方走，最后落到前沿上，不同起点落到不同位置。下面的定理说明能够保证的是什么。

定理 26.17 多梯度下降的收敛 设每个 f_i 有下界 f_i^{low}，∇f_i 是 L_i-Lipschitz 的，记 $L_{\max} = \max_i L_i$。设迭代满足式 (26.29)，且 $\alpha^{(t)} \geq \alpha_{\min} > 0$。则对任意目标 i 和任意 $T \geq 1$，

$$\min_{0 \leq t < T} \|\bar{\boldsymbol{g}}^{(t)}\|_2^2 \leq \frac{f_i(\boldsymbol{x}^{(0)}) - f_i^{\mathrm{low}}}{c\, \alpha_{\min} T}. \tag{26.32}$$

并且序列的每个极限点都是 Pareto 驻定点。固定步长 $\alpha = 1/L_{\max}$，$c = 1/2$ 时满足条件，式 (26.32)的右端为 $2L_{\max}(f_i(\boldsymbol{x}^{(0)}) - f_i^{\mathrm{low}})/T$。

证明 由式 (26.29)，对每个 t，

$$f_i(\boldsymbol{x}^{(t+1)}) \leq f_i(\boldsymbol{x}^{(t)}) - c\, \alpha_{\min} \|\bar{\boldsymbol{g}}^{(t)}\|_2^2.$$

对 $t = 0, \ldots, T-1$ 求和，利用 $f_i(\boldsymbol{x}^{(T)}) \geq f_i^{\mathrm{low}}$，得到

$$c\, \alpha_{\min} \sum_{t=0}^{T-1} \|\bar{\boldsymbol{g}}^{(t)}\|_2^2 \leq f_i(\boldsymbol{x}^{(0)}) - f_i^{\mathrm{low}}.$$

最小项不超过平均值，即得式 (26.32)。这一和式也说明 $\|\bar{\boldsymbol{g}}^{(t)}\|_2 \to 0$。

记 $\varphi(\boldsymbol{x})$ 为点 $\boldsymbol{x}$ 处的 $\|\bar{\boldsymbol{g}}\|_2$。对任意 $\boldsymbol{x}, \boldsymbol{y}$，设 θ 是 $\boldsymbol{y}$ 处的最优系数，

$$\varphi(\boldsymbol{x}) \le \Big\|\sum_i \theta_i \nabla f_i(\boldsymbol{x})\Big\|_2 \le \varphi(\boldsymbol{y}) + L_{\max}\|\boldsymbol{x}-\boldsymbol{y}\|_2.$$

交换 $\boldsymbol{x}, \boldsymbol{y}$，两式合起来给出

$$|\varphi(\boldsymbol{x}) - \varphi(\boldsymbol{y})| \le L_{\max}\|\boldsymbol{x}-\boldsymbol{y}\|_2,$$

所以 φ 连续。沿收敛子列取极限，极限点处 $\varphi = 0$，由引理 26.15它是 Pareto 驻定点。

固定步长的情形由式 (26.29)之后的不等式给出。 ■

定理的结论是 $\|\bar{\boldsymbol{g}}\|_2$ 趋于零，也就是逼近 Pareto 驻定。根据第 26.3.1节，这不等于全局 Pareto 最优；凸问题中，再加上极限处权重全正，才能推到 Pareto 最优。回溯时取 $\alpha_{\min} = \min\{1, \beta/L_{\max}\}$ 即可满足定理的条件，因为一旦 $\alpha \le 1/L_{\max}$ 就会被接受。

与固定加权的对比 图 26.23比较了从 $(4,0)$ 出发的两种迭代。这一点的目标值是 $(8, 4.5)$。固定权重 $(1/2, 1/2)$ 的梯度法（黄色）走向该偏好下的解 $(2.41, 5.64)$，f_1 降了很多，但 f_2 从 4.5 升到了 5.64。多梯度下降（绿色）停在 $(6.99, 3.04)$，两个目标都比起点好。

这两个结果没有谁对谁错。前者忠实地执行了“两项同样重要”的偏好，后者忠实地执行了“不让任何一项变差”的要求。一次运行得到的都只是前沿上的一个点。

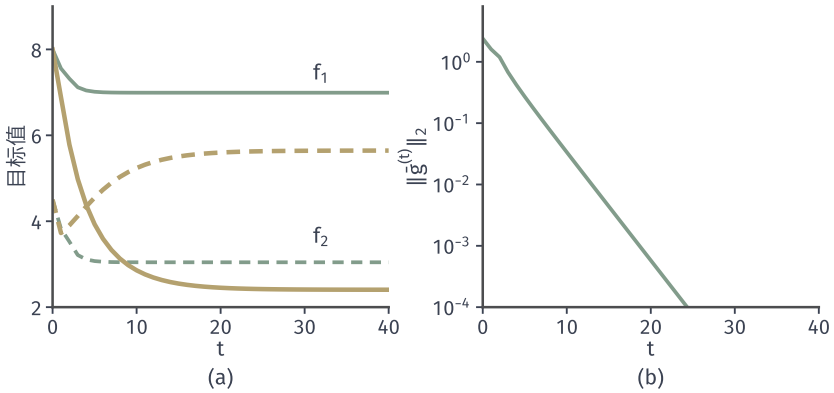


图 26.23 从 $(4,0)$ 出发的迭代，例 (26.30)。(a) 实线是 f_1，虚线是 f_2，绿色是多梯度下降，黄色是固定权重 $(1/2,1/2)$、步长 $1/L$ 的梯度法，后者使 f_2 上升。(b) 多梯度下降的 $\|\bar{\boldsymbol{g}}^{(t)}\|_2$，纵轴为对数。

26.1 多目标问题
26.2 标量化
26.3 最优解的判别
26.4 多梯度下降
26.5 前沿的计算
26.5.1 参数扫描
26.5.2 非支配排序
26.6 前沿的评价
26.7 本章小结

有约束时 可行集 $\boldsymbol{C}$ 是闭凸集时，把式 (26.28)限制到可行方向上：

$$\boldsymbol{d}^{(t)} \in \arg\min_{\boldsymbol{x}^{(t)}+\boldsymbol{d}\in\boldsymbol{C}} \max_i \langle \boldsymbol{g}_i^{(t)}, \boldsymbol{d}\rangle + \frac{1}{2}\|\boldsymbol{d}\|_2^2. \tag{26.33}$$

$\boldsymbol{d}=\boldsymbol{0}$ 是可行的，目标值是 0。由强凸性解唯一，所以 $\boldsymbol{d}^{(t)}\neq\boldsymbol{0}$ 时最优值严格小于零，$\max_i\langle \boldsymbol{g}_i^{(t)}, \boldsymbol{d}^{(t)}\rangle < 0$，$\boldsymbol{d}^{(t)}$ 是共同下降方向。由 $\boldsymbol{C}$ 凸，$\boldsymbol{x}^{(t)}+\alpha\boldsymbol{d}^{(t)}$ 在 $\alpha\in(0,1]$ 时可行，沿它做共同步长的回溯即可。

反过来，若存在可行点 $\boldsymbol{x}^{(t)}+\boldsymbol{v}$ 使 $\langle \boldsymbol{g}_i^{(t)}, \boldsymbol{v}\rangle < 0$ 对所有 i 成立，取足够小的 $\tau>0$，方向 $\tau\boldsymbol{v}$ 的目标值就小于零，于是 $\boldsymbol{d}=\boldsymbol{0}$ 不是解。所以 $\boldsymbol{d}^{(t)}=\boldsymbol{0}$ 说明从当前点沿可行集内的方向不存在共同下降，这对应第 26.3.2节的驻定条件。$\boldsymbol{C}$ 是多面体时，式 (26.33)可以写成一个二次规划。

一次多梯度下降通常只给出前沿上的一个点。要得到一组候选，就要进入下一节。

26.5 前沿的计算

决策者常常要先看到各种取舍，再做决定。这就要求算出一组候选，而不是一个点。单次标量化或一次多梯度下降都只给出前沿上的一点，所以要么反复求解，要么同时维护多个候选。本节分别讨论这两条路：由偏好参数驱动的重复求解，和由支配关系驱动的群体搜索。

26.5.1 参数扫描

把权重、阈值或参考点变化一遍，每次解一个单目标问题，能否得到一组分布合理的候选？这一小节要说明，参数均匀并不等于前沿均匀，并给出按空缺补充求解的办法。

均匀的参数不等于均匀的前沿 在例 (26.4)上，由式 (26.11)，取 $w=0,1/4,1/2,3/4,1$，得到前沿上的五个点

$$(1,0),\quad (0.5625,0.0625),\quad (0.25,0.25),\quad (0.0625,0.5625),\quad (0,1).$$

相邻两点的距离依次约为 $0.442, 0.364, 0.364, 0.442$，不算均匀，但差得不多。

如果两个目标的尺度悬殊，差别就大了。例 (26.30)的加权和有显式解，由 $w\boldsymbol{g}_1+(1-w)\boldsymbol{g}_2=\boldsymbol{0}$ 逐分量解出

$$\boldsymbol{x}(w)=\Big(4(1-w),\ \frac{3(1-w)}{8w+1}\Big). \tag{26.34}$$

图 26.24(a) 是 11 个均匀的 w 所对应的点，点都挤在左上方，右下方有一个大空缺。按目标范围归一化后，相邻点间距最大约为 0.665，最小约为 0.089。

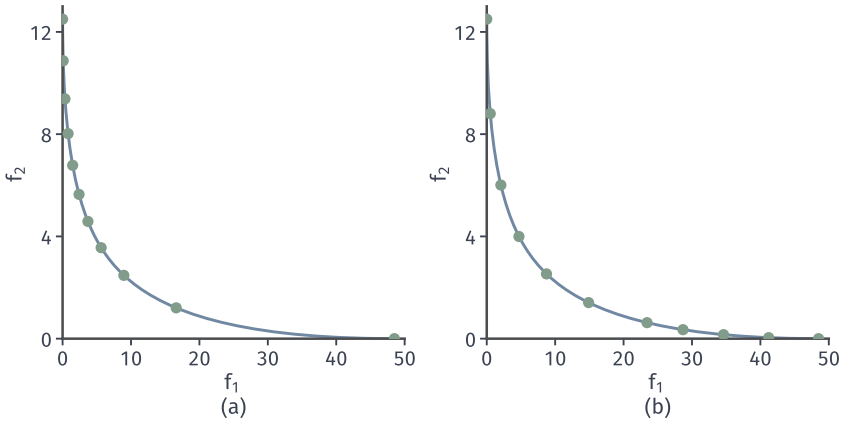


图 26.24 例 (26.30)前沿上的 11 个候选。(a)w 在 $[0,1]$ 上均匀取值，点集中在左上方。(b) 按最大空缺逐次补点，权重取空缺两端连线的法向。两图的端点相同。

按空缺补点 既然均匀的参数靠不住，就让已经算出的点来决定下一个参数。对凸前沿，下面的过程很自然。

先用两个端点权重算出两端的点。然后反复做这样一步：找出归一化后间距最大的相邻两点 $\boldsymbol{p},\boldsymbol{q}$，取这两点连线的法向作为新的权重，

$$w=\frac{|q_2-p_2|}{|q_2-p_2|+|q_1-p_1|}, \tag{26.35}$$

求解相应的加权和，把新点插进去。新权重下，支撑线与连线平行，解是这段前沿上离连线最远的点。若解不比 $\boldsymbol{p},\boldsymbol{q}$ 的连线更靠左下，说明这一段已经没有新的支撑点，把这段标记为完成。

在例 (26.4)上走几步。两端是 $(0,1)$ 和 $(1,0)$，由式 (26.35)得 $w=1/2$，由式 (26.11)得新点 $(1/4,1/4)$。

在 $(0,1)$ 与 $(1/4,1/4)$ 之间，两个差值是 $3/4$ 和 $1/4$，权重为

$$w=\frac{3/4}{3/4+1/4}=\frac{3}{4},$$

新点是 $(1/16,9/16)$。在 $(1/4,1/4)$ 与 $(1,0)$ 之间，同理 $w=1/4$，新点是 $(9/16,1/16)$。五个点到此与均匀权重的结果相同，继续补点时，算法开始根据实际空缺分配求解次数。

在例 (26.30)上，按这种做法得到图 26.24(b)，归一化间距的最大值降到约 0.296，最小值约为 0.111，同样 11 次求解分布均匀得多。这里的选取规

则只用到已算出的点，但法向的含义依赖目标尺度，所以要先说明归一化的参考范围。

用邻近问题的解作初值 相邻参数的解通常相隔不远，这启发了用上一个解作下一个问题的初值，称为**热启动**（warm start）。图 26.25比较了两种做法：用梯度法解 39 个加权子问题，步长取该子问题的 $1/L$，梯度范数降到 10^{-3} 为止。

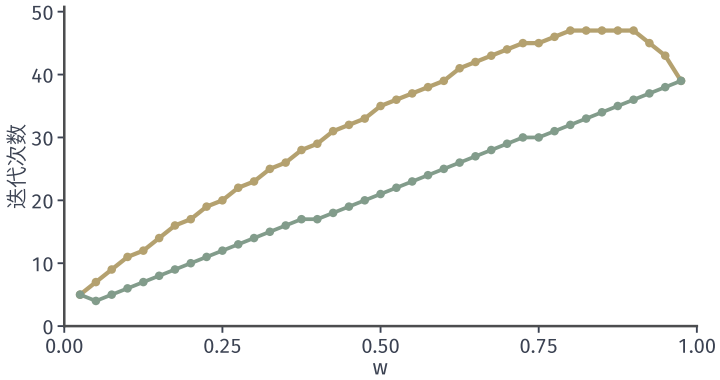


图 26.25 例 (26.30)的 39 个加权子问题所用的梯度法迭代次数，w 每步增加 0.025。黄线是每次从 $(0,2)$ 冷启动，共 1232 步；绿线是从上一个解热启动，共 826 步。

总迭代次数从 1232 降到 826。线性收敛的方法从更好的初值出发，节省的是迭代次数对数中的一项，收敛速率本身不变，所以这里只节省三分之一左右，高精度要求下比例还会更小。

保存非支配候选 扫描得到的点不一定都有用：求解可能不精确，并列解可能只是弱 Pareto 最优点。所以要维护一个**非支配存档**（non-dominated archive）。新点进来时，若被存档中的点支配就丢弃；否则把它支配的旧点删掉，再加入存档。

按 A, E, B, F, C, D 的顺序把式 (26.3)中的候选送入存档。A 进入；E 与 A 不可比，进入；B 支配 E，把 E 换成 B；F 与已有的点不可比，进入；C 也进入；D 支配 F，把 F 换成 D。最后得到 $\{A, B, C, D\}$。

可达性的限制仍然存在 无论参数取得多细，每种标量化能到达的点不会变多。图 26.26在带凹陷的前沿上各取九个均匀的参数。加权和在 $w \geq 0.7$ 的三次求解全落到端点，凹陷段里一个点也没有，点从 $(0.577, 0.183)$ 直接跳到 $(0.206, 0.633)$。阈值约束和加权 Chebyshev 都把点放进了凹陷。

26.1 多目标问题
26.2 标量化
26.3 最优解的判别
26.4 多梯度下降
26.5 前沿的计算
26.5.1 参数扫描
26.5.2 非支配排序
26.6 前沿的评价
26.7 本章小结

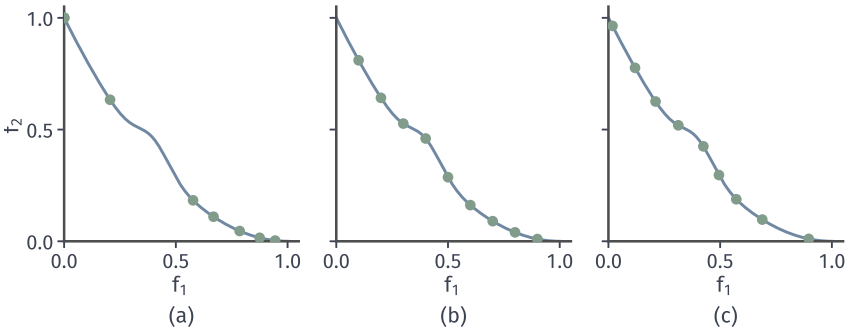


图 26.26 带凹陷的前沿上三种标量化的扫描，每种取九个均匀参数。(a) 加权和，$w = 0.1, \ldots, 0.9$，$w \geq 0.7$ 的三点重合在左端。(b) 阈值约束，$\tau = 0.1, \ldots, 0.9$。(c) 加权 Chebyshev，$\boldsymbol{z} = (-0.1, -0.1)$，$\boldsymbol{w} = (w, 1-w)$。

所以，在非凸前沿上，要用阈值约束或加权 Chebyshev 来做扫描，并且每次求解都要检查是否达到全局最优。若子问题只解到局部最优，定理 26.6和定理 26.7的保证都不再适用。

26.5.2 非支配排序

参数扫描每次只优化一个点。能不能让一批候选同时朝前沿移动，并在前沿上散开？这一小节以 NSGA-II 为例，说明怎样把第 15章的种群搜索改造成服务前沿近似的算法。

主要思想 NSGA-II（non-dominated sorting genetic algorithm II）沿用遗传算法的框架，维护一个规模为 N 的种群，变异和重组都与第 15章相同。要改造的是选择：单目标时按代价排序就能分出好坏，这里目标是向量，排序要回答两个问题。

第一个问题是谁离前沿更近。把种群按支配关系分层，不被任何个体支配的点是第一层；把第一层去掉后，剩下的点中不被支配的是第二层，依此类推。这个过程称为**非支配排序**（non-dominated sorting）。层号越小越靠近前沿。

第二个问题是同一层内谁应当保留。同一层的点互不支配，排不出优劣，但我们希望点在前沿上散开。所以优先保留周围比较空的点，用**拥挤距离**（crowding distance）度量。

对一层的点集，按目标 k 排序，设点 $\boldsymbol{y}$ 的前后邻点为 $\boldsymbol{y}^-$ 和 $\boldsymbol{y}^+$，该层在目标 k 上的范围为 R_k，拥挤距离是

$$D(\boldsymbol{y}) = \sum_{k=1}^{m} \frac{y_k^+ - y_k^-}{R_k}. \tag{26.36}$$

每个目标上的两个端点取 $D = \infty$，这样最大的和最小的值总被保留。式 (26.36)是以邻点为角的长方体的周长的一种度量。除以 R_k 使不同尺度的目标能够相加，也因此依赖该层的取值范围。

还有一个改造：下一代从亲代与后代的并集中选出，这就是**精英保留**（elitism）的做法，和第 15章的 $(\mu + \lambda)$ 选择相同。好的亲代不会因后代变差而丢失。图 26.27是一代的流程。

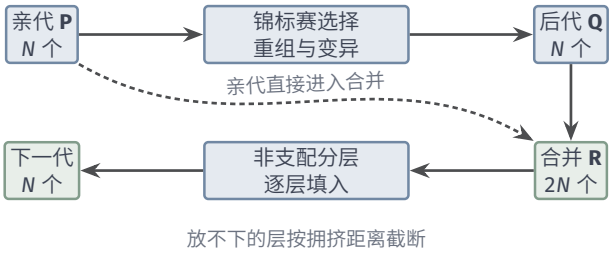


图 26.27 NSGA-II 的一代。亲代经锦标赛选择、重组与变异产生后代，亲代与后代合并成 $2N$ 个候选，分层后逐层填入下一代，最后放不下的那一层按拥挤距离从大到小取。

变量

- 种群 $\boldsymbol{P}$，N 个候选及其目标向量，每个候选的层号与拥挤距离；
- 后代 $\boldsymbol{Q}$，N 个候选；合并的集合 $\boldsymbol{R} = \boldsymbol{P} \cup \boldsymbol{Q}$；
- 分层计算中的辅助量：$S_{\boldsymbol{p}}$ 是 $\boldsymbol{p}$ 支配的点集，$n_{\boldsymbol{p}}$ 是支配 $\boldsymbol{p}$ 的点数。

初始化 随机产生 N 个候选并评价，分层并计算拥挤距离。下面用例子说明一代中的选择。假设合并后得到八个候选，它们是式 (26.3)的六个点，加上

$$G = (3, 7), \qquad H = (6, 7).$$

每轮更新

1. 产生后代：用二元锦标赛选亲代，比较时层号小者胜，层号相同时拥挤距离大者胜；再做重组和变异。例中假定后代已经产生并合并。
2. 合并亲代和后代，对每一点计算 $n_{\boldsymbol{p}}$ 和 $S_{\boldsymbol{p}}$。例中

$$n_A = n_B = n_C = n_D = 0, \quad n_E = 2, \quad n_F = n_G = 1, \quad n_H = 5.$$

   E 被 B, C 支配，F 被 D 支配，G 被 B 支配，H 被 B, C, D, E, G 支配。
3. 分层：$n_{\boldsymbol{p}} = 0$ 的点组成第一层，把它们支配的点的 n 减一，n 减到零的点组成下一层，依此类推。例中第一层是 $\{A, B, C, D\}$。把它们去掉后 $n_E = n_G = n_F = 0$，第二层是 $\{E, F, G\}$，第三层是 $\{H\}$，见图 26.28(a)。

4. 逐层填入下一代，直到某一层放不下。例中取 $N=6$，第一层四个点全部进入，还差两个名额。

5. 放不下的那一层，计算拥挤距离 (26.36)，按从大到小取够。例中第二层 G,E,F 按 f_1 排序是 G,E,F，G,F 是端点，距离为无穷；E 的距离是

$$D(E)=\frac{7-3}{7-3}+\frac{7-1}{7-1}=2.$$

所以取 G 和 F，E 被淘汰。下一代是 $\{A,B,C,D,F,G\}$。

这一例也提醒我们，F 虽然只是弱 Pareto 最优点，却因为端点的身份进入了下一代。分层只反映种群内部的关系。

截断也可能发生在第一层。若 $N=3$，第一层四个点要留三个。A 和 D 是端点，距离为无穷。其余两点的距离由式 (26.36)算出：

$$D(B)=\frac{4-1}{5}+\frac{8-4}{7}\approx 1.171,\qquad D(C)=\frac{6-2}{5}+\frac{5-1}{7}\approx 1.371.$$

所以保留 A,C,D，淘汰 B，图 26.28(b) 画出了这两个长方形。C 在加权和下永远选不上，在这里却因为不拥挤而被留下：种群搜索的比较只用支配和距离，不要求支撑。

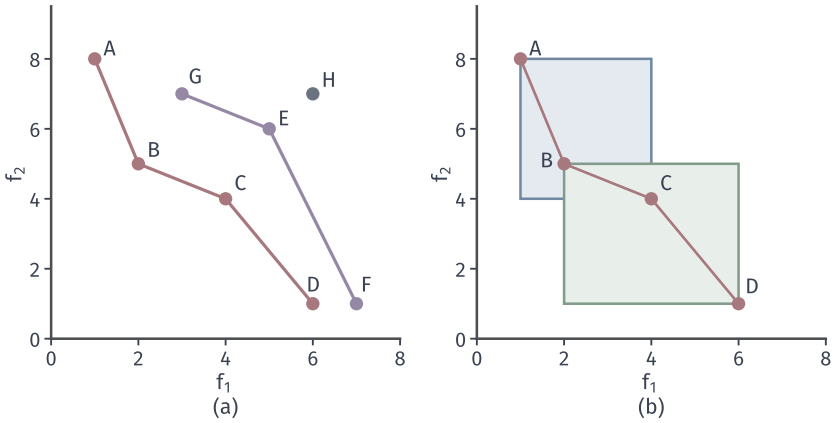


图 26.28　八个候选的非支配排序与拥挤距离。(a) 红色、紫色、灰色依次是第一、二、三层。(b) 第一层内 B 与 C 的拥挤长方形，分别以 A,C 和 B,D 为角，C 的长方形更大。

运行效果　一代中比较支配关系的开销是 $O(mN^2)$，拥挤距离的排序是 $O(mN\log N)$，加上 N 次目标评价。目标评价昂贵时，主要开销是评价的次数。

图 26.29是在一个五维问题上的实际运行。取 $\boldsymbol{x}\in[0,1]^5$，

$$f_1=x_1,\quad \gamma=1+\frac{9}{4}\sum_{j=2}^{5}x_j,\quad f_2=\gamma\Big(1-\big(f_1/\gamma\big)^2\Big).\tag{26.37}$$

26.1 多目标问题
26.2 标量化
26.3 最优解的判别
26.4 多梯度下降
26.5 前沿的计算
26.6 前沿的评价
26.6.1 候选质量
26.6.2 覆盖范围
26.7 本章小结

当 $x_2 = \cdots = x_5 = 0$ 时 $\gamma = 1$，$f_2 = 1 - f_1^2$，这就是式 (26.12)的抛物线前沿。其余变量把点往上推。种群规模为 40，运行 200 代，随机种子固定。

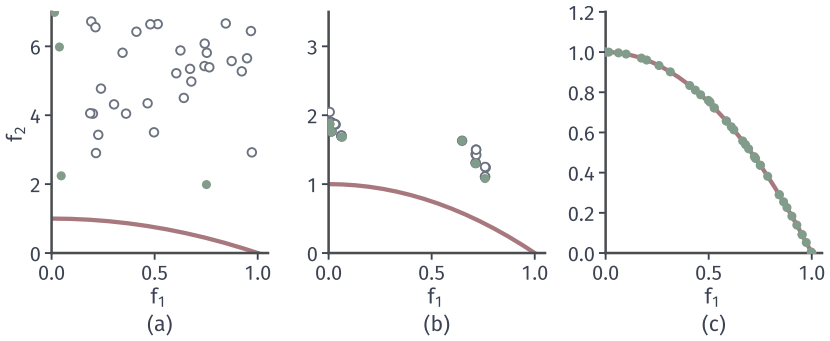


图 26.29 NSGA-II 在式 (26.37)上的种群，种群规模 40。红线是真实前沿，绿点是当前种群的第一层，空心点是其余个体。(a) 初始种群。(b) 第 10 代，第一层有 12 个点，互不支配，但离前沿还很远。(c) 第 200 代，40 个点都在前沿附近。三幅图的纵轴范围不同。

第 10 代的 12 个点互不支配，却离真实前沿还很远。这正是必须记住的一点：有限种群内部互不支配，不能说明它们是 Pareto 最优的。算法没有全局保证，它的结果要靠第 26.6节的量来检查。加权和扫描在这个问题上只能得到两个端点，这里的种群搜索能把点散布到整条前沿上，这是它的优势。

26.6 前沿的评价

算法交出了一组候选，这组候选好不好？真实前沿通常是未知的，所以要明确：在固定目标尺度和计算预算的情况下，能报告哪些可计算的量，它们分别说明什么。本节先看单个候选的质量，再看整组候选的覆盖范围。

26.6.1 候选质量

一个候选点要检查什么？这一小节列出三项检查：是否可行，它自己的子问题解得好不好，以及是否还有共同下降的余地。

约束违反 第一项是可行性。对每个候选报告最大约束违反量

$$\operatorname{viol}(\boldsymbol{x}) = \max\Big\{\max_j [g_j(\boldsymbol{x})]_+,\ \max_k |h_k(\boldsymbol{x})|\Big\}, \tag{26.38}$$

其中 $[v]_+ = \max\{v, 0\}$。违反约束的点不能参与支配比较：稍微违反约束的点常常看起来更好，让它留在候选集中，会把真正可行的点错误地淘汰掉。

两种残差 第二项是该候选作为优化结果的误差，这要看它是怎么得来的，要回答的问题也不同。

若候选来自权重 $\boldsymbol{w}$ 的无约束加权和，就看它作为这个单目标问题的解有多准，用**标量子问题误差**（scalar subproblem error）衡量，光滑无约束时常用梯度范数

$$\rho_{\boldsymbol{w}}(\boldsymbol{x}) = \Big\| \sum_{i=1}^{m} w_i \nabla f_i(\boldsymbol{x}) \Big\|_2 . \tag{26.39}$$

若候选是作为 Pareto 驻定点提交的，要看的是**共同下降残差**（common descent residual）$\|\bar{\boldsymbol{g}}(\boldsymbol{x})\|_2$，也就是式 (26.25)中的最短长度。

这两种残差回答的问题不同。由于 $\bar{\boldsymbol{g}}$ 是所有凸组合中最短的，对任意 $\boldsymbol{w} \in \Delta_m$，

$$\|\bar{\boldsymbol{g}}(\boldsymbol{x})\|_2 \le \rho_{\boldsymbol{w}}(\boldsymbol{x}). \tag{26.40}$$

标量残差小，共同下降残差必定也小；反过来不成立。

在例 (26.4)上算两个候选，权重都取 $(1/2, 1/2)$。第一个候选 $\hat{\boldsymbol{x}} = (0.9, 0.1)$ 在解集上，

$$\boldsymbol{g}_1 = (-0.1, 0.1), \qquad \boldsymbol{g}_2 = (0.9, -0.9).$$

两个梯度反向，$\|\bar{\boldsymbol{g}}\|_2 = 0$，它是驻定的。但

$$\rho_{\boldsymbol{w}} = \|(0.4, -0.4)\|_2 \approx 0.566.$$

所以这个点是前沿上的一点，却不是“两项同样重要”这个偏好下的解。

第二个候选 $\hat{\boldsymbol{x}} = (0.6, 0.5)$ 略微偏离解集，

$$\boldsymbol{g}_1 = (-0.4, 0.5), \qquad \boldsymbol{g}_2 = (0.6, -0.5).$$

由式 (26.27)算出 $\theta^\star = 0.55$，$\bar{\boldsymbol{g}} = (0.05, 0.05)$，其长度约为 0.071；而 $\rho_{\boldsymbol{w}} = \|(0.1, 0)\|_2 = 0.1$。两个残差都不为零，式 (26.40)成立。

图 26.30把这种差别沿着整条线段画了出来：解集上共同下降残差处处为零，标量残差却只在 $s = 1/2$ 处为零。偏离解集的距离加入后，两种残差都不再为零。所以报告残差时要说清楚是哪一种。若目的是“实现这个偏好”，就看 $\rho_{\boldsymbol{w}}$；若目的是“候选不能再被一阶共同改进”，就看 $\|\bar{\boldsymbol{g}}\|_2$。

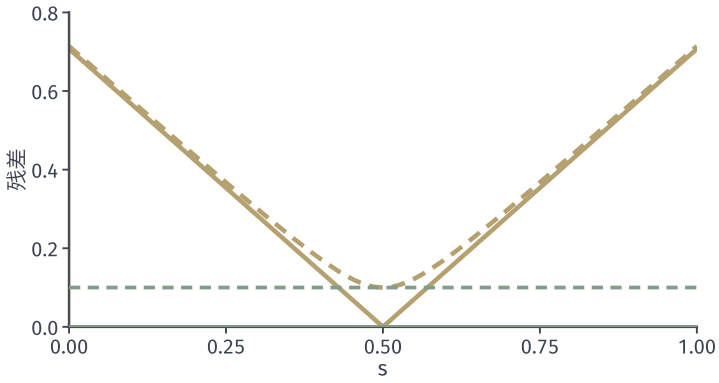


图 26.30 例 (26.4)中两种残差沿 $\boldsymbol{x}(s) = (1-s, s) + \delta(1,1)/\sqrt{2}$ 的变化。绿线是共同下降残差，黄线是 $\boldsymbol{w} = (1/2, 1/2)$ 的标量残差，实线为 $\delta = 0$，虚线为 $\delta = 0.1$。

约束问题中，$\rho_{\boldsymbol{w}}$ 和 $\|\bar{\boldsymbol{g}}\|_2$ 要换成相应的 KKT 残差，即式 (26.23)的左端在给定乘子下的范数，再加上互补松弛的误差。

筛选的局限 第三项是把候选集中被支配的点剔除，用第 26.5.1节的存档方法即可。剔除之后剩下的点互不支配，但这只是在已有候选之间比较。

图 26.31中，A, B, C, D 互不支配。如果有一个没被算到的方案 $\boldsymbol{P} = (3, 3)$，它支配 C，粉色区域中的方案都比它差。有限候选之间的筛选，永远不能证明不存在尚未找到的支配方案。

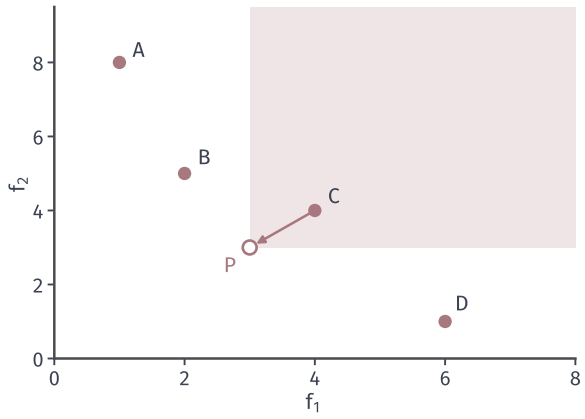


图 26.31 有限候选的筛选不足以判定最优。红点 A, B, C, D 互不支配，尚未找到的方案 $\boldsymbol{P} = (3, 3)$（红色空心点）却支配 C，C 落在 $\boldsymbol{P}$ 的被支配区域（粉色）中。

证明一个候选是全局 Pareto 最优的办法有两种：问题是凸的，用定理 26.14；或者全局求解一个能够选中它的标量子问题。两种都不能依靠候选之间的比较。

26.1 多目标问题
26.2 标量化
26.3 最优解的判别
26.4 多梯度下降
26.5 前沿的计算
26.6 前沿的评价
26.6.1 候选质量
26.6.2 覆盖范围
26.7 本章小结

26.6.2 覆盖范围

单个候选合格，整组未必合格，它们可能都挤在前沿的一小段上。这一小节讨论怎样用数字描述整组候选的质量，以及每个数字的局限。

超体积 取一个比所有候选都差的**参考点** $\boldsymbol{r}$，也就是各分量都大于候选相应分量的点。候选集 $\boldsymbol{S}$ 支配的、并被 $\boldsymbol{r}$ 界住的区域的体积称为**超体积**（hypervolume）：

$$\mathrm{HV}(\boldsymbol{S};\boldsymbol{r}) = \mathrm{vol}\Big(\bigcup_{\boldsymbol{y}\in\boldsymbol{S}} \{\boldsymbol{z} : \boldsymbol{y} \le \boldsymbol{z} \le \boldsymbol{r}\}\Big). \tag{26.41}$$

一个指标把“离前沿多近”和“覆盖多宽”都包含进来：候选越靠前沿，被支配区域越大；候选越分散，并集越大。

两个目标时超体积可以按条带求和。把候选按 f_1 从小到大排序，设互不支配，记第 i 点为 $(y_{1,i}, y_{2,i})$，$i = 1, \dots, N$，并约定 $y_{1,N+1} = r_1$。则

$$\mathrm{HV} = \sum_{i=1}^{N} (y_{1,i+1} - y_{1,i})(r_2 - y_{2,i}). \tag{26.42}$$

对 A, B, C, D 取 $\boldsymbol{r} = (8, 9)$，四个条带的面积是

$$(2-1)(9-8) = 1, \quad (4-2)(9-5) = 8, \quad (6-4)(9-4) = 10, \quad (8-6)(9-1) = 16,$$

总和 $\mathrm{HV} = 35$，见图 26.32。把 E 或 F 加进来，超体积不变，因为它们支配的区域已经被覆盖。把 C 去掉，超体积变成 33，C 独占的贡献是 $(6-4)(5-4) = 2$。

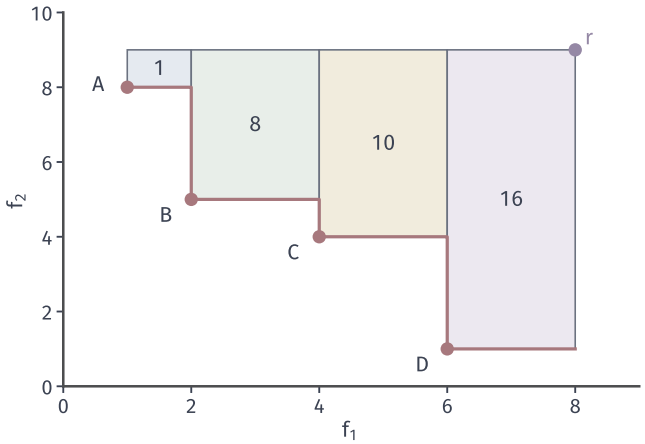


图 26.32 A, B, C, D 的超体积，参考点 $\boldsymbol{r} = (8, 9)$。彩色条带的面积分别是 $1, 8, 10, 16$，合计 35。红色阶梯线是这组候选支配区域的左下边界。

超体积的好处在于它和支配关系是相容的。

定理 26.18 超体积的单调性 设 S, S' 的所有点都逐分量不大于 r。若对每个 $y' \in S'$，存在 $y \in S$ 使 $y \preceq y'$，则

$$\mathrm{HV}(S; r) \geq \mathrm{HV}(S'; r). \tag{26.43}$$

证明 若 $y \preceq y' \preceq z \preceq r$，则 $y \preceq z \preceq r$。所以 S' 对应的并集包含在 S 对应的并集中，体积不减。 ■

也就是说，把一组候选换成支配它们的另一组，超体积不会下降。

参考点和尺度 超体积不是一个自足的数字，它依赖参考点。设 $S_1 = \{(1,6),(6,1)\}$，$S_2 = \{(3,3)\}$。取 $r = (7,7)$，由式 (26.42)，

$$\mathrm{HV}(S_1) = 5 \times 1 + 1 \times 6 = 11, \qquad \mathrm{HV}(S_2) = 4 \times 4 = 16.$$

S_2 更好。取 $r = (20,20)$，

$$\mathrm{HV}(S_1) = 5 \times 14 + 14 \times 19 = 336, \qquad \mathrm{HV}(S_2) = 17 \times 17 = 289.$$

S_1 更好。参考点越远，越看重前沿的两端，见图 26.33。比较不同算法时，参考点必须事先固定，并且和结果一起报告。

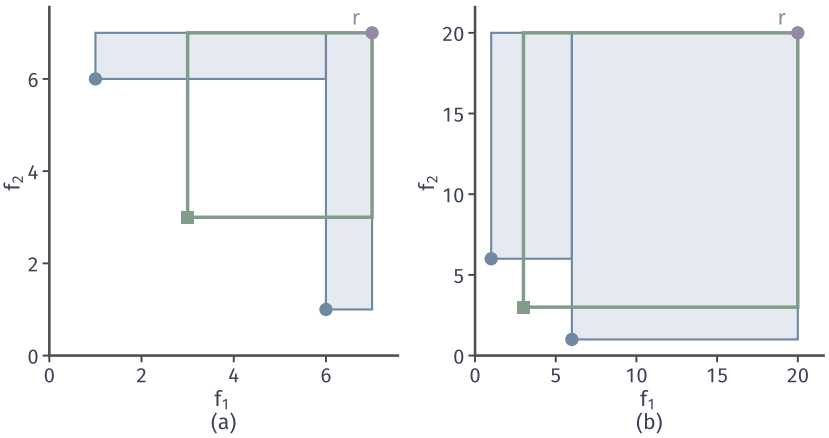


图 26.33 超体积比较依赖参考点。蓝色区域属于 $S_1 = \{(1,6),(6,1)\}$，绿色方框属于 $S_2 = \{(3,3)\}$。(a)$r = (7,7)$，S_2 较大。(b)$r = (20,20)$，S_1 较大。

尺度的影响也要说明。把目标 k 乘以 $c > 0$，参考点相应乘以 c，所有超体积同乘 c，比较结果不变。但把目标归一化时，若参考范围随候选集而变，每组候选用的就是不同的尺子，比较便失去了共同的基准。

空缺与取舍范围 超体积把很多信息压成一个数，可能掩盖分布上的差别。还要报告相邻候选之间的最大间距和目标的取舍范围。

在例 (26.4)的前沿上，用 s 值表示候选，取 $\boldsymbol{S}_1$ ： $s = 0.1, 0.5, 0.9$ 与 $\boldsymbol{S}_2$ ： $s = 0.24, 0.515, 0.975$。取 $\boldsymbol{r} = (1.2, 1.2)$，两者的超体积都等于 1.0897，见图 26.34。可是把前沿两端也算上，$\boldsymbol{S}_1$ 的最大相邻间距约为 0.609，$\boldsymbol{S}_2$ 约为 0.724，$\boldsymbol{S}_2$ 在靠 f_2 轴的一端空出了更大的一段。

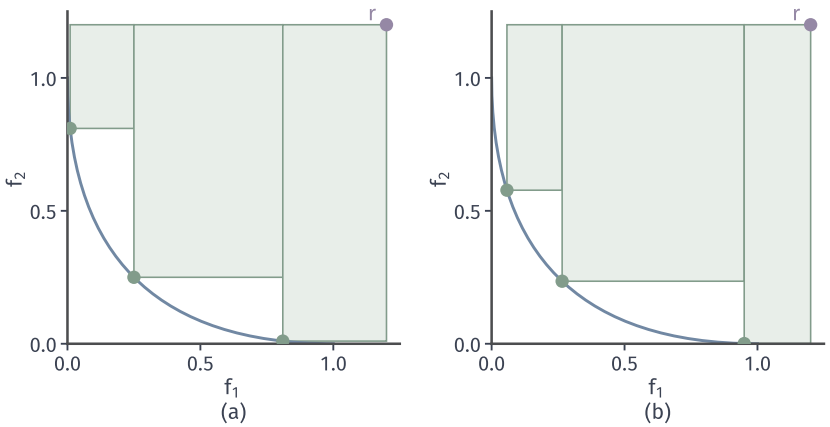


图 26.34 两组超体积相同（$\boldsymbol{r} = (1.2, 1.2)$，HV = 1.0897）的候选，蓝线是真实前沿。(a)$s = 0.1, 0.5, 0.9$。(b)$s = 0.24, 0.515, 0.975$，最大相邻间距更大。

到参考前沿的距离 若有可信的参考前沿 $\boldsymbol{R}$，比如问题有解析解，或者是长时间计算汇总的结果，可以进一步计算候选集与它的距离。两个常用的量是**世代距离**（generational distance，GD）和**反向世代距离**（inverted generational distance，IGD）：

$$\begin{aligned} \mathrm{GD} &= \frac{1}{|\boldsymbol{S}|} \sum_{\boldsymbol{y} \in \boldsymbol{S}} \min_{\boldsymbol{p} \in \boldsymbol{R}} \|\boldsymbol{y} - \boldsymbol{p}\|_2, \\ \mathrm{IGD} &= \frac{1}{|\boldsymbol{R}|} \sum_{\boldsymbol{p} \in \boldsymbol{R}} \min_{\boldsymbol{y} \in \boldsymbol{S}} \|\boldsymbol{y} - \boldsymbol{p}\|_2. \end{aligned} \tag{26.44}$$

GD 看候选离前沿有多近，IGD 看前沿被候选覆盖得多好。图 26.34的两组候选都在前沿上，GD 都是零。IGD 用 1001 个参考点计算，$\boldsymbol{S}_1$ 约为 0.143，$\boldsymbol{S}_2$ 约为 0.163，这里区分出了两组候选的覆盖差别。

这些量都要有参考前沿才能算。若参考前沿是其他算法的结果，算出的就只是相对的差别，不是真实误差。

多个指标一起看 图 26.35是图 26.29那次运行的指标曲线，参考点取 $\boldsymbol{r} = (1.1, 1.1)$。超体积在第 40 代已经到 0.512，真实前沿对应的值是 0.5433，第 200 代是 0.5245。到参考前沿的平均距离第 100 代约为 0.0141，第 200 代约为 0.0153，并不单调。

26.1 多目标问题
26.2 标量化
26.3 最优解的判别
26.4 多梯度下降
26.5 前沿的计算
26.6 前沿的评价
26.7 本章小结

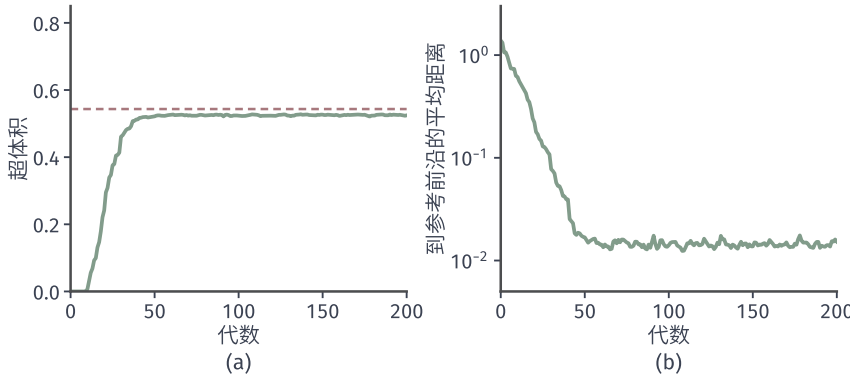


图 26.35 NSGA-II 运行中的指标，问题为式 (26.37)。(a) 超体积，$\boldsymbol{r} = (1.1, 1.1)$，红色虚线是真实前沿的值 0.5433。(b) 种群第一层到参考前沿的 IGD，纵轴为对数。曲线后段不是单调的。

种群只有 40 个点，覆盖不了整条曲线，超体积不会达到 0.5433，这个差额来自有限的点数。同一种群的第一层不断变化时，IGD 也可以上下波动。不能用一个集合指标代替所有判断。表 26.3列出各个量各自回答的问题。

表 26.3 候选集的常用评价量。

量	回答的问题	需要的条件
约束违反	是否可行	约束函数
标量残差	这次偏好解得准不准	权重或阈值
共同下降残差	还能否一阶共同改进	梯度
超体积	支配区域多大	固定的 $\boldsymbol{r}$ 与尺度
最大间距	前沿上有无大空缺	目标尺度
GD 与 IGD	离参考前沿多近	可信的参考前沿

把这些量都算出来，能说的话仍然有限：这组候选满足约束，单点的残差如此，在这个参考点下超体积如此。不能说“已经恢复了完整的 Pareto 前沿”，除非另有理论保证。

26.7 本章小结

本章从“两个目标各有所长的方案谁更好”出发。结论是，不依赖偏好的比较只有支配关系，由它得到的是一组互不支配的方案，而不是一个方案。目标冲突不会因为单目标算法更强而消失，强的算法只能更快地解出某一个偏好下的问题。

支配关系是第一层判断，它不受单位影响。权重、距离和归一化都依赖尺度，使用时要写明单位与参考范围。

偏好由三种标量化表达。加权和相当于定价，权重全正的全局解是 Pareto 最优的，凸问题中非负权重足以选中每个弱 Pareto 最优点，但在非凸前沿上会遗漏非支撑点。阈值约束相当于定预算，加权 Chebyshev 相当于要求各项接近某个水平，二者不需要凸性就能选中每个 Pareto 点，但可能返回并列的弱 Pareto 最优解，需要第二阶段的择优。

局部信息给出一阶判别。Pareto 驻定说明不存在严格共同下降的方向，这是局部弱 Pareto 最优的必要条件，有约束时要在约束资格下配合乘子；要由它推出全局结论，还需要凸性，权重全正时才能得到 Pareto 最优。多梯度下降从梯度凸包的最小范数元得到共同下降方向，配合共同步长使每个目标都下降，一次运行收敛到一个驻定点。

要得到一组候选，可以扫描偏好参数，用热启动降低代价，按空缺补点，并用非支配存档保存结果；也可以用 NSGA-II 这样的群体搜索，以分层和拥挤距离代替单目标的排序。两者都要在固定的目标尺度下，用约束违反、残差、超体积、间距以及到参考前沿的距离来检查。

图 26.36汇总了四种结果之间的关系。加权最优、Pareto 驻定、全局 Pareto 最优和有限候选集的覆盖是四种不同的结论，从一种到另一种都需要说明所依赖的条件。

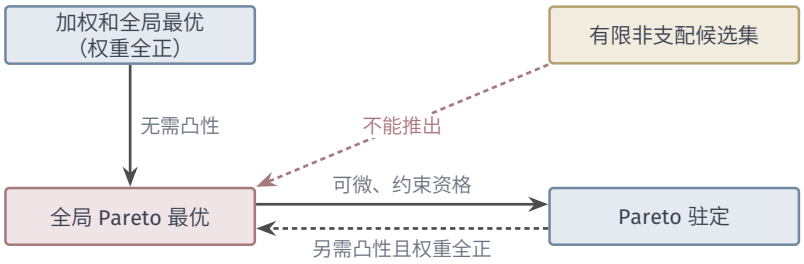


图 26.36　四种结果的关系。实线箭头在标注的条件下成立，虚线箭头需要额外的条件，红色虚线表示有限候选集互不支配不能推出全局 Pareto 最优。

27.1 极小极大问题
27.1.1 响应顺序
27.1.2 模型边界
27.2 最坏值函数
27.3 鞍点
27.4 内层响应法
27.5 下降—上升方法
27.6 校正方向
27.7 结果评价
27.8 本章小结

第 27 章

极小极大优化

一个设定值 x 定下来之后，实际需求 y 还会在 $[-1,1]$ 内变动，偏差的代价是 $(x-y)^2$。如果要求方案在允许范围内最坏的情形下也过得去，x 该怎样选？取 $x=0.5$，最坏的需求是 $y=-1$，代价是 2.25；取 $x=0$，最坏的代价是 1。评价一个方案不再是算一个函数值，而是要先解一个最大化问题。

这类问题的外层要让代价小，内层要让同一个代价大。两层方向相反，带来三个单目标问题里没有的困难：先选谁会改变答案；内层最优的 y 随 x 切换，外层目标因此可能没有导数；两组变量一起迭代时，轨迹可能绕着解打转而不靠近它。

第 27.1节把决策顺序写成准确的数学问题。第 27.2节把内层收进一个只依赖 $\boldsymbol{x}$ 的函数，研究它何时有意义、何时可微。第 27.3节回答两个次序何时给出同一个值，并给出检验一对候选的数值证书。

求解有两条路线。第 27.4节沿决策顺序先求内层响应，再更新外层。第 27.5节和第 27.6节让两组变量同时走，先看最直接的做法为什么会失败，再用校正方向修复。第 27.7节说明算完之后拿什么证据判断结果的好坏。

27.1 极小极大问题

“先定方案，再承受最坏的响应”，怎样写成一个含义准确的优化问题？

设 $\boldsymbol{X}\subseteq\mathbb{R}^n$，$\boldsymbol{Y}\subseteq\mathbb{R}^q$ 是预先给定、互不依赖的非空集合，$f:\boldsymbol{X}\times\boldsymbol{Y}\to\mathbb{R}$ 是代价。$\boldsymbol{x}$ 是方案，$\boldsymbol{y}$ 是允许的响应。我们研究

$$\inf_{\boldsymbol{x}\in\boldsymbol{X}}\ \sup_{\boldsymbol{y}\in\boldsymbol{Y}}\ f(\boldsymbol{x},\boldsymbol{y}), \tag{27.1}$$

称为**极小极大问题**（minimax problem）。这个式子要从里往外读：对每个固定的 $\boldsymbol{x}$，内层求 $\boldsymbol{x}$ 所能遭遇的最坏代价；外层在所有方案中选最坏代价最小的那个。

内层面对的是一个已经选定的 $\boldsymbol{x}$，它不是一个可以脱离外层单独解出来的优化问题。在开头的例子里，$x=0.5$ 时最坏的 y 是 -1，$x=-0.5$ 时最

27.1 极小极大问题
27.1.1 响应顺序
27.1.2 模型边界
27.2 最坏值函数
27.3 鞍点
27.4 内层响应法
27.5 下降—上升方法
27.6 校正方向
27.7 结果评价
27.8 本章小结

坏的 y 是 1。单独问“最坏的 y 是什么”没有答案，内层实际上是一族问题，每个 $\boldsymbol{x}$ 对应一个。

把内层的 sup 换成 inf，情况完全不同。两层都最小化时，

$$\inf_{\boldsymbol{x}\in\boldsymbol{X}}\inf_{\boldsymbol{y}\in\boldsymbol{Y}} f(\boldsymbol{x},\boldsymbol{y}) = \inf_{(\boldsymbol{x},\boldsymbol{y})\in\boldsymbol{X}\times\boldsymbol{Y}} f(\boldsymbol{x},\boldsymbol{y}),$$

两层可以合并成一个联合最小化，这正是第 12章能够交替更新各块的前提。极小极大问题做不到这一点，一个变量要下山，另一个变量要上山，没有一个共同的目标能把两者合起来。

27.1.1 响应顺序

先用一张有限的代价表看次序的作用。有两个方案 a, b 和两种扰动，代价如图 27.1所示。

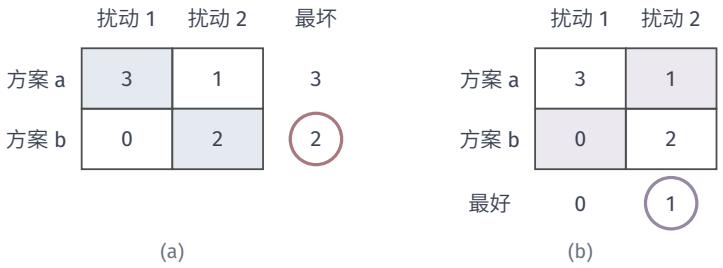


图 27.1 同一张代价表，两种决策顺序。(a) 先定方案：每行取最大（蓝底），最坏列在表右，再在两个最坏值中取小，得到红圈中的 2。(b) 先定扰动：每列取最小（紫底），最好列在表下，再在两个最好值中取大，得到紫圈中的 1。

先定方案、再来扰动时，方案 a 的最坏代价是 3，方案 b 的最坏代价是 2，所以选 b，代价是 2。这就是式 (27.1)的次序。

反过来，先定扰动、再选方案时，扰动 1 下最好的方案代价是 0，扰动 2 下最好的方案代价是 1。扰动一方要让代价大，所以选扰动 2，代价是 1。两个次序写成

$$\min_{\text{方案}}\max_{\text{扰动}} = 2, \qquad \max_{\text{扰动}}\min_{\text{方案}} = 1.$$

同一张表给出两个不同的数。差别来自信息：后选的一方看得到先选的一方，可以对症下药。选方案的一方后选时代价是 1，先选时代价是 2，多出来的 1 是先亮底牌的代价。

后选不吃亏这件事不依赖具体的表。

引理 27.1 弱极小极大不等式 对任意非空集合 $\boldsymbol{X}, \boldsymbol{Y}$ 和任意 $f : \boldsymbol{X} \times \boldsymbol{Y} \to \mathbb{R}$，

$$\sup_{\boldsymbol{y}\in\boldsymbol{Y}} \inf_{\boldsymbol{x}\in\boldsymbol{X}} f(\boldsymbol{x},\boldsymbol{y}) \le \inf_{\boldsymbol{x}\in\boldsymbol{X}} \sup_{\boldsymbol{y}\in\boldsymbol{Y}} f(\boldsymbol{x},\boldsymbol{y}). \tag{27.2}$$

证明 任取 $\boldsymbol{x}' \in \boldsymbol{X}$ 和 $\boldsymbol{y}' \in \boldsymbol{Y}$。下确界不超过其中任何一项，上确界不小于其中任何一项，所以

$$\inf_{\boldsymbol{x}\in\boldsymbol{X}} f(\boldsymbol{x},\boldsymbol{y}') \le f(\boldsymbol{x}',\boldsymbol{y}') \le \sup_{\boldsymbol{y}\in\boldsymbol{Y}} f(\boldsymbol{x}',\boldsymbol{y}).$$

最左端不含 $\boldsymbol{x}'$，最右端不含 $\boldsymbol{y}'$。左端对 $\boldsymbol{y}'$ 取上确界，右端对 $\boldsymbol{x}'$ 取下确界，不等号保持。 ■

连续的例子也一样。回到开头的 $f(x,y) = (x-y)^2$，$X = \mathbb{R}$，$Y = [-1,1]$。固定 x 时，f 是 y 的凸函数，最大值在端点取到，所以

$$\sup_{y\in[-1,1]} (x-y)^2 = \max\{(x+1)^2, (x-1)^2\} = (|x|+1)^2.$$

上式在 $x = 0$ 处最小，于是先定方案的值是 1。反过来，无论 y 是多少，后选的 x 都可以取 $x = y$，使代价为零，所以先定扰动的值是 0。图 27.2(a) 里，外层最小化的是粗蓝线，而不是任何一条细线。

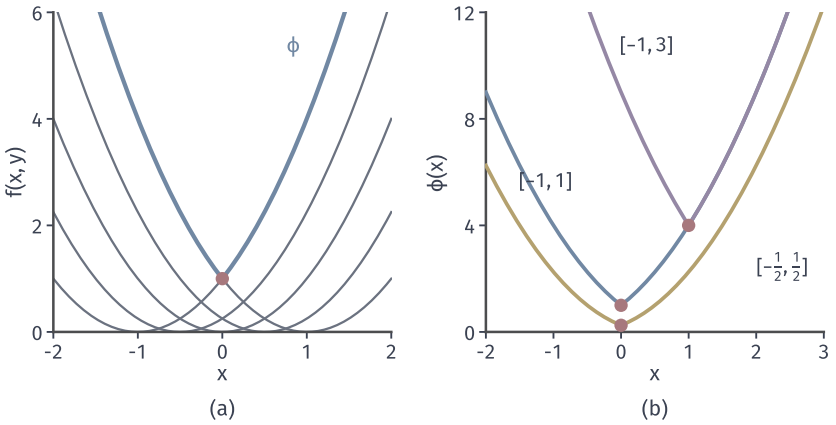


图 27.2 $f(x,y) = (x-y)^2$ 的最坏代价。(a) 灰线是 $y = 0, \pm\frac{1}{2}, \pm 1$ 时的 $f(\cdot, y)$，蓝线是它们对全部 $y \in [-1,1]$ 的上边缘 $\phi(x) = (|x|+1)^2$，红点是外层最优解。(b) 三种响应集合下的最坏代价，黄线、蓝线、紫线分别对应标注的集合，红点是各自的最优解。集合 $[-1,3]$ 把最优解移到了 $x = 1$。

式 (27.2)的等号一般不成立，上面两个例子都严格小于。所以式 (27.1)里 inf 和 sup 的次序是问题的一部分，不能随手交换。交换需要额外的条件，第 27.3节专门研究。

27.1 极小极大问题
27.1.1 响应顺序
27.1.2 模型边界
27.2 最坏值函数
27.2.1 响应切换
27.2.2 值函数导数
27.3 鞍点
27.4 内层响应法
27.5 下降—上升方法
27.6 校正方向
27.7 结果评价
27.8 本章小结

27.1.2 模型边界

极小极大的结论只对写进模型的 $\boldsymbol{Y}$ 负责。“最坏”指的是集合 $\boldsymbol{Y}$ 里最坏，集合之外的情形不在保证之内。

图 27.2(b) 比较了三个响应集合。对对称的集合 $[-\rho,\rho]$，同样的计算给出最坏代价 $(|x|+\rho)^2$，最优解都是 $x=0$，最优值是 ρ^2。集合放大时值变大，解却碰巧没动，这很容易让人以为解不依赖集合。

换成不对称的 $Y=[-1,3]$，最坏代价变成

$$\max\{(x+1)^2,(x-3)^2\}.$$

两条抛物线在 $x=1$ 相交，最优解是 $x=1$，最优值是 4。按 $Y=[-1,1]$ 选出的 $x=0$，放到这个更大的集合下，最坏代价是 $(0-3)^2=9$，比 4 差很多。一般地，$\boldsymbol{Y}_1\subseteq\boldsymbol{Y}_2$ 时内层上确界只会变大，所以小集合上的最坏值只是大集合上最坏值的下界，小集合上的最优解在大集合上没有任何保证。

Lagrange 鞍点是特例 第 18章已经见过这种结构。约束问题的 Lagrange 函数 $\mathcal{L}$ 对乘子取上确界时，可行点得到 $f(\boldsymbol{x})$，不可行点得到 $+\infty$，原问题因此写成

$$\inf_{\boldsymbol{x}\in\boldsymbol{D}}\ \sup_{\boldsymbol{\lambda}\geq\boldsymbol{0},\,\boldsymbol{\nu}}\ \mathcal{L}(\boldsymbol{x},\boldsymbol{\lambda},\boldsymbol{\nu}).$$

这相当于在式 (27.1)中取 $\boldsymbol{y}=(\boldsymbol{\lambda},\boldsymbol{\nu})$，$\boldsymbol{Y}=\mathbb{R}^m_+\times\mathbb{R}^p$，$\boldsymbol{X}=\boldsymbol{D}$。对偶问题是交换次序后的 sup inf，弱对偶就是式 (27.2)。这个特例的结构比一般情形简单，$\mathcal{L}$ 关于 $\boldsymbol{y}$ 是线性的，并且 $\boldsymbol{Y}$ 由符号约束给出。本章的 f 不必有这种结构，$\boldsymbol{Y}$ 也可以是任意给定的集合。

本章不讨论的内容 本章只有一个固定的代价 f，$\boldsymbol{y}$ 只是“允许的响应”这个数学对象，不代表一个有自身偏好的决策者。模型中各方的偏好、均衡的解释和随时间展开的策略属于另一类问题，可参考卷十第 8 章“静态博弈与均衡”。这里只研究静态问题 (27.1)及其数值求解。

27.2 最坏值函数

外层真正面对的目标是什么？本节把内层收进一个只依赖 $\boldsymbol{x}$ 的函数，然后研究这个函数的性质，因为外层能用什么算法，全由这些性质决定。

27.1 极小极大问题
27.2 最坏值函数
27.2.1 响应切换
27.2.2 值函数导数
27.3 鞍点
27.4 内层响应法
27.5 下降—上升方法
27.6 校正方向
27.7 结果评价
27.8 本章小结

定义 27.2　最坏值函数　称

$$\phi(\boldsymbol{x}) = \sup_{\boldsymbol{y}\in\boldsymbol{Y}} f(\boldsymbol{x},\boldsymbol{y}) \tag{27.3}$$

为**最坏值函数**（worst-case value function），它在某些点上可以取 $+\infty$。上确界能够达到时，记最优响应的集合为

$$\boldsymbol{Y}^{\star}(\boldsymbol{x}) = \{\boldsymbol{y}\in\boldsymbol{Y} : f(\boldsymbol{x},\boldsymbol{y}) = \phi(\boldsymbol{x})\}. \tag{27.4}$$

问题 (27.1)于是成为普通的单层问题 $\inf_{\boldsymbol{x}\in\boldsymbol{X}} \phi(\boldsymbol{x})$。难点全部转移到了 ϕ 上：它的每个函数值都要解一次最大化，它未必处处有限，也未必光滑。

有一点性质不需要任何计算。若对每个 $\boldsymbol{y}\in\boldsymbol{Y}$，$f(\cdot,\boldsymbol{y})$ 都是凸函数，则 ϕ 是凸函数，因为对任意 $\theta\in[0,1]$，

$$f(\theta\boldsymbol{x}_1+(1-\theta)\boldsymbol{x}_2,\boldsymbol{y}) \le \theta f(\boldsymbol{x}_1,\boldsymbol{y})+(1-\theta)f(\boldsymbol{x}_2,\boldsymbol{y}) \le \theta\phi(\boldsymbol{x}_1)+(1-\theta)\phi(\boldsymbol{x}_2),$$

再对 $\boldsymbol{y}$ 取上确界即可。这里对 $\boldsymbol{y}$ 一侧没有任何要求，$(x-y)^2$ 关于 y 是凸的，ϕ 照样是凸的。

内层可能出现三种不同的状况，它们影响的事情也不同，见表 27.1。

内层的状况	影响什么	反例
最坏值有限	问题在该 $\boldsymbol{x}$ 处是否有意义	$f=xy$，$Y=\mathbb{R}$
上确界达到	内层能否解出一个响应	$f=x^2-e^{-y}$，$Y=\mathbb{R}$
最优响应唯一	外层是否可微	$f=xy$，$Y=[-1,1]$，$x=0$

表 27.1　内层的三种状况及其影响。反例说明相应性质可能失败。

第一行里，$x\neq 0$ 时 $\sup_{y\in\mathbb{R}} xy=+\infty$，只有 $x=0$ 处最坏值有限。第二行里 $\phi(x)=x^2$ 有限，但 $-e^{-y}$ 在 $y\to+\infty$ 时只是趋于 0，没有哪个 y 达到上确界，内层的算法会一直往无穷远走。第三行里 $x=0$ 时 $f\equiv 0$，每个 y 都是最优响应。

27.2.1 响应切换

光滑的 f 是否给出光滑的 ϕ？最简单的例子已经说明不会。取 $f(x,y)=xy$，$Y=[-1,1]$。f 关于 y 线性，最大值在端点，于是

$$\phi(x) = \max\{x,-x\} = |x|. \tag{27.5}$$

每条直线 $f(\cdot,y)$ 都光滑，它们的上边缘在原点却有折角，见图 27.3(a)。原因是起作用的响应在 $x=0$ 处换了人：$x>0$ 时最优响应是 $y=1$，$x<0$

时是 $y=-1$。外层目标的尖点，正是内层最优响应切换的地方。这个切换与第 11章有限个函数取最大值时活跃分支的交替是同一个机制，只是这里的分支可能有无穷多条。

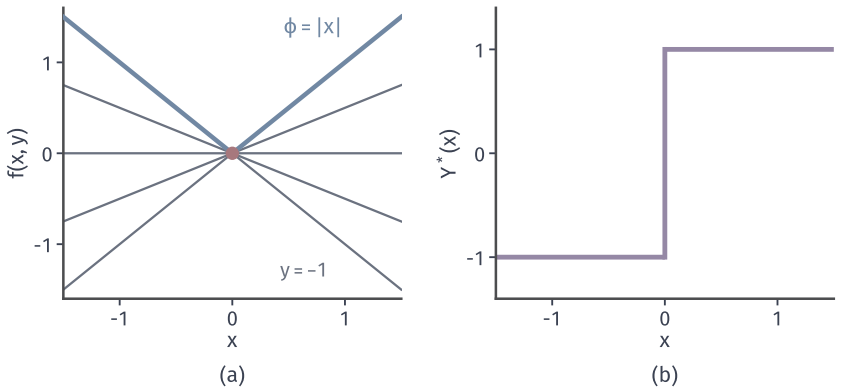


图 27.3　$f(x,y)=xy$，$Y=[-1,1]$。(a) 灰线是 $y=0,\pm\frac{1}{2},\pm1$ 时的直线，蓝线是上边缘 $\phi(x)=|x|$，红点是外层最优解。(b) 紫线是最优响应集合 $Y^\star(x)$ 的图像，在 $x=0$ 处是一整条竖直线段。

图 27.3(b) 画出了 $Y^\star(x)$。在 $x\neq 0$ 处它是单点，在 $x=0$ 处是整个区间，这说明最优响应应当看作集合值映射。$(x-y)^2$ 的情形更极端：$Y^\star(0)=\{-1,1\}$ 是两个分开的点，集合甚至不连通。

下面的定理给出响应集合紧时能够保证的全部好性质。它说明响应集合可以跳，但图像是闭的，ϕ 本身仍然连续。

定理 27.3　紧响应集上的最坏值函数　设 $\boldsymbol{Y}$ 非空且紧，f 在 $\boldsymbol{X}\times\boldsymbol{Y}$ 上连续。则

1. 对每个 $\boldsymbol{x}\in\boldsymbol{X}$，上确界达到，$\boldsymbol{Y}^\star(\boldsymbol{x})$ 非空且紧；
2. ϕ 在 $\boldsymbol{X}$ 上有限且连续；
3. 若 $\boldsymbol{x}_k\to\boldsymbol{x}$，$\boldsymbol{y}_k\in\boldsymbol{Y}^\star(\boldsymbol{x}_k)$，$\boldsymbol{y}_k\to\bar{\boldsymbol{y}}$，则 $\bar{\boldsymbol{y}}\in\boldsymbol{Y}^\star(\boldsymbol{x})$。

证明　第一条。$f(\boldsymbol{x},\cdot)$ 是紧集上的连续函数，最大值存在。$\boldsymbol{Y}^\star(\boldsymbol{x})$ 是连续函数 $f(\boldsymbol{x},\cdot)$ 的水平集，是紧集 $\boldsymbol{Y}$ 的闭子集，所以紧。

第二条。设 $\boldsymbol{x}_k\to\boldsymbol{x}$。集合 $\boldsymbol{K}=\{\boldsymbol{x}_k\}\cup\{\boldsymbol{x}\}$ 是紧的，f 在紧集 $\boldsymbol{K}\times\boldsymbol{Y}$ 上一致连续。记

$$\delta_k=\max_{\boldsymbol{y}\in\boldsymbol{Y}}|f(\boldsymbol{x}_k,\boldsymbol{y})-f(\boldsymbol{x},\boldsymbol{y})|\to 0.$$

27.1 极小极大问题
27.2 最坏值函数
27.2.1 响应切换
27.2.2 值函数导数
27.3 鞍点
27.4 内层响应法
27.5 下降—上升方法
27.6 校正方向
27.7 结果评价
27.8 本章小结

对任意 $\boldsymbol{y}$，有

$$f(\boldsymbol{x}_k, \boldsymbol{y}) \le f(\boldsymbol{x}, \boldsymbol{y}) + \delta_k \le \phi(\boldsymbol{x}) + \delta_k.$$

对 $\boldsymbol{y}$ 取最大，得到 $\phi(\boldsymbol{x}_k) \le \phi(\boldsymbol{x}) + \delta_k$。交换 $\boldsymbol{x}_k$ 与 $\boldsymbol{x}$ 的角色，得到 $\phi(\boldsymbol{x}) \le \phi(\boldsymbol{x}_k) + \delta_k$。所以 $\phi(\boldsymbol{x}_k) \to \phi(\boldsymbol{x})$。

第三条。由 $\boldsymbol{y}_k$ 的最优性，$f(\boldsymbol{x}_k, \boldsymbol{y}_k) = \phi(\boldsymbol{x}_k)$。令 $k \to \infty$，用 f 和 ϕ 的连续性，得到 $f(\boldsymbol{x}, \bar{\boldsymbol{y}}) = \phi(\boldsymbol{x})$。 ■

第三条对应图 27.3(b) 的形状：从左右两侧趋于 $x = 0$ 时响应趋于 ± 1，这两个极限都落在 $Y^\star(0)$ 里。反过来不成立，$Y^\star(0)$ 中的 $y = \frac{1}{2}$ 不是任何邻近点响应的极限，所以这个映射不是连续的。

27.2.2 值函数导数

要用梯度类方法更新 $\boldsymbol{x}$，需要 ϕ 的导数，而 ϕ 本身没有显式表达式。能不能不微分内层的解？

看图 27.4(a)。在 $x = 0.5$ 处，起作用的是 $y = -1$ 这条抛物线，上边缘在这里与它相切。切线的斜率就是这条抛物线在 $x = 0.5$ 处关于 x 的导数。y 本身随 x 怎样变，在一阶上不起作用，因为 y 已经处在最优位置，朝任何可行方向挪动，代价都不会一阶增加。

第 19章的 Danskin 型结果给出了精确的说法。那里研究固定集合 $\boldsymbol{C}$ 上的最优值函数 $V(\theta)$，把它用到 $-f$ 上，记号换成本章的，就得到下面的结论，证明见该章。

定理 27.4　最坏值函数的方向导数　设 $\boldsymbol{X} \subseteq \mathbb{R}^n$ 开，$\boldsymbol{Y}$ 非空且紧，f 与 $\nabla_{\boldsymbol{x}} f$ 在 $\boldsymbol{X} \times \boldsymbol{Y}$ 上连续。则对每个 $\boldsymbol{x} \in \boldsymbol{X}$ 和方向 $\boldsymbol{d}$，

$$\phi'(\boldsymbol{x}; \boldsymbol{d}) = \max_{\boldsymbol{y} \in Y^\star(\boldsymbol{x})} \langle \nabla_{\boldsymbol{x}} f(\boldsymbol{x}, \boldsymbol{y}), \boldsymbol{d} \rangle. \tag{27.6}$$

若 $Y^\star(\boldsymbol{x}) = \{\boldsymbol{y}^\star(\boldsymbol{x})\}$ 是单点，则 ϕ 在 $\boldsymbol{x}$ 处可微，且

$$\nabla \phi(\boldsymbol{x}) = \nabla_{\boldsymbol{x}} f(\boldsymbol{x}, \boldsymbol{y}^\star(\boldsymbol{x})). \tag{27.7}$$

式 (27.6)取最大值，是因为沿方向 $\boldsymbol{d}$ 走一小步之后，起作用的是在这个方向上增长最快的那条响应。在开头的例子里，$\nabla_x f = 2(x - y)$。$x = 0.5$ 时响应唯一，$y^\star = -1$，式 (27.7)给出

$$\phi'(0.5) = 2(0.5 + 1) = 3.$$

它与直接求导 $\phi'(x) = 2(x+1)$ 的结果一致。

在 $x = 0$ 处，$Y^\star(0) = \{-1, 1\}$，两个响应的偏导数是 2 和 -2。式 (27.6)给出

$$\phi'(0; d) = \max\{2d, -2d\} = 2|d|.$$

直接展开，得到

$$\phi(d) - \phi(0) = (|d| + 1)^2 - 1 = 2|d| + d^2,$$

一阶部分相同。

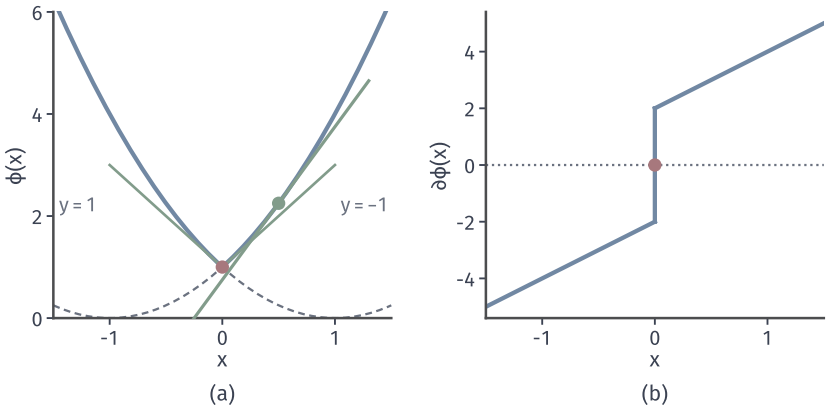


图 27.4 $\phi(x) = (|x| + 1)^2$ 的导数信息。(a) 灰色虚线是 $y = \pm 1$ 两条抛物线，蓝线是上边缘。绿点 $x = 0.5$ 处只有一条活动响应，绿线是斜率为 3 的切线。红点 $x = 0$ 处两条响应同时活动，两段绿线的斜率是 ± 2。(b) 次微分的集值图像，在 $x = 0$ 处是竖直线段 $[-2, 2]$，它穿过点线 0，说明 $x = 0$ 是最优解。

条件的作用 定理要求响应集固定。这个条件去掉，公式就错了。取 $f(x, y) = y$，让响应集随方案移动，$Y(x) = [-1, x]$，$x > -1$。则 $\phi(x) = x$，导数是 1，而 $\partial f/\partial x \equiv 0$。漏掉的部分来自集合边界的移动，要由乘子计入，这正是第 19章一般含参约束的内容。本章 $\boldsymbol{Y}$ 不依赖 $\boldsymbol{x}$，这个问题不出现。

紧性也不能省。$\boldsymbol{Y}$ 不紧时响应可能不存在，式 (27.6)的右端失去意义，表 27.1第二行就是这样。

关于 $\boldsymbol{x}$ 凸时的次梯度集合 多响应时只有方向导数还不够方便。若 f 关于 $\boldsymbol{x}$ 凸，ϕ 是凸函数，可以用第 11章的次微分：$\boldsymbol{g}$ 是 ϕ 在 $\boldsymbol{x}$ 处的次梯度，指对所有 $\boldsymbol{x}'$ 都有

$$\phi(\boldsymbol{x}') \geq \phi(\boldsymbol{x}) + \langle \boldsymbol{g}, \boldsymbol{x}' - \boldsymbol{x} \rangle.$$

该章对有限个函数的最大值证明了次微分是活跃梯度的凸包，下面的定理把分支数推广到紧集上的无穷多个。

定理 27.5　最坏值函数的次微分　设 $\boldsymbol{X}=\mathbb{R}^n$，$\boldsymbol{Y}$ 非空且紧，f 与 $\nabla_{\boldsymbol{x}} f$ 连续，且对每个 $\boldsymbol{y}\in\boldsymbol{Y}$，$f(\cdot,\boldsymbol{y})$ 是凸函数。则

$$\partial\phi(\boldsymbol{x})=\operatorname{conv}\bigl\{\nabla_{\boldsymbol{x}} f(\boldsymbol{x},\boldsymbol{y}):\boldsymbol{y}\in\boldsymbol{Y}^{\star}(\boldsymbol{x})\bigr\}. \tag{27.8}$$

证明　记右端为 $\boldsymbol{K}$。$\boldsymbol{Y}^{\star}(\boldsymbol{x})$ 是紧集，它在连续映射 $\nabla_{\boldsymbol{x}} f(\boldsymbol{x},\cdot)$ 下的像也是紧集，$\mathbb{R}^n$ 中紧集的凸包仍是紧集，所以 $\boldsymbol{K}$ 紧且凸。

先证 $\boldsymbol{K}\subseteq\partial\phi(\boldsymbol{x})$。任取 $\boldsymbol{y}\in\boldsymbol{Y}^{\star}(\boldsymbol{x})$ 和 $\boldsymbol{x}'$。由 ϕ 的定义和 $f(\cdot,\boldsymbol{y})$ 的凸性，

$$\phi(\boldsymbol{x}')\ge f(\boldsymbol{x}',\boldsymbol{y})\ge f(\boldsymbol{x},\boldsymbol{y})+\langle\nabla_{\boldsymbol{x}} f(\boldsymbol{x},\boldsymbol{y}),\boldsymbol{x}'-\boldsymbol{x}\rangle.$$

左边第二项的 $f(\boldsymbol{x},\boldsymbol{y})$ 等于 $\phi(\boldsymbol{x})$。把这样的不等式按凸组合的权重相加，右端的向量就换成了 $\boldsymbol{K}$ 中的任意元素。

再证反向。设 $\boldsymbol{g}\in\partial\phi(\boldsymbol{x})$ 但 $\boldsymbol{g}\notin\boldsymbol{K}$。$\boldsymbol{K}$ 非空、闭、凸，由第 18章 点与闭凸集的严格分离，存在 $\boldsymbol{d}$，使

$$\langle\boldsymbol{g},\boldsymbol{d}\rangle>\max_{\boldsymbol{c}\in\boldsymbol{K}}\langle\boldsymbol{c},\boldsymbol{d}\rangle\ge\max_{\boldsymbol{y}\in\boldsymbol{Y}^{\star}(\boldsymbol{x})}\langle\nabla_{\boldsymbol{x}} f(\boldsymbol{x},\boldsymbol{y}),\boldsymbol{d}\rangle=\phi'(\boldsymbol{x};\boldsymbol{d}).$$

最后的等号是式 (27.6)。

另一方面，次梯度不等式给出

$$\phi(\boldsymbol{x}+s\boldsymbol{d})-\phi(\boldsymbol{x})\ge s\langle\boldsymbol{g},\boldsymbol{d}\rangle.$$

除以 $s>0$ 并令 $s\downarrow 0$，得到

$$\phi'(\boldsymbol{x};\boldsymbol{d})\ge\langle\boldsymbol{g},\boldsymbol{d}\rangle.$$

这与上式矛盾。 ■

对开头的例子，活动偏导数是 ± 2，所以 $\partial\phi(0)=[-2,2]$，见图 27.4(b)。对 $f=xy$，活动偏导数是 $|y|\le 1$ 的全体 y，所以 $\partial\phi(0)=[-1,1]$。两者都含 0，所以 $x=0$ 都是全局最优解。

多响应时要注意一件事：只取其中一个响应，它给出的梯度未必是下降方向。在 $(x-y)^2$ 的 $x=0$ 处，取 $y=1$，偏导数是 -2，沿负偏导数方向是把 x 往正的方向移，而 ϕ 沿这个方向是上升的。这和第 11章次梯度的负方向未必下降是同一回事。值函数的导数和次梯度只回答“外层目标对 $\boldsymbol{x}$ 怎样变化”；$\boldsymbol{Y}$ 或约束也随参数变化时的完整敏感性，由第 19章处理。

27.3 鞍点

27.1 极小极大问题
27.2 最坏值函数
27.3 鞍点
27.3.1 最值交换
27.3.2 鞍点间隙
27.4 内层响应法
27.5 下降—上升方法
27.6 校正方向
27.7 结果评价
27.8 本章小结

判断一个 $\boldsymbol{x}$ 好不好，要算 $\phi(\boldsymbol{x})$，也就要解一次内层。如果手上同时有一个 $\boldsymbol{x}$ 和一个 $\boldsymbol{y}$，能不能让它们互相作证？本节研究这样一对候选应当满足什么关系，它和两个次序的值有什么联系。

记交换次序后的函数为

$$\psi(\boldsymbol{y}) = \inf_{\boldsymbol{x}\in\boldsymbol{X}} f(\boldsymbol{x},\boldsymbol{y}), \tag{27.9}$$

它是 $\boldsymbol{y}$ 先定时外层能做到的最好代价。两个次序的值分别记作

$$\bar{v} = \inf_{\boldsymbol{x}\in\boldsymbol{X}} \phi(\boldsymbol{x}), \qquad \underline{v} = \sup_{\boldsymbol{y}\in\boldsymbol{Y}} \psi(\boldsymbol{y}). \tag{27.10}$$

式 (27.2)就是 $\underline{v} \le \bar{v}$。

想象一个山口。沿着山脊方向，山口是最低点；沿着翻山的方向，山口是最高点。站在山口，往山脊两头走都要上坡，往两侧山谷走都要下坡。下面的定义把这个图景用到两组变量上：沿 $\boldsymbol{x}$ 的方向山口最低，沿 $\boldsymbol{y}$ 的方向山口最高。

定义 27.6　全局鞍点　若 $(\boldsymbol{x}^\star,\boldsymbol{y}^\star)\in\boldsymbol{X}\times\boldsymbol{Y}$ 对所有 $\boldsymbol{x}\in\boldsymbol{X}$，$\boldsymbol{y}\in\boldsymbol{Y}$ 满足

$$f(\boldsymbol{x}^\star,\boldsymbol{y}) \le f(\boldsymbol{x}^\star,\boldsymbol{y}^\star) \le f(\boldsymbol{x},\boldsymbol{y}^\star), \tag{27.11}$$

就称它是 f 在 $\boldsymbol{X}\times\boldsymbol{Y}$ 上的**全局鞍点**（global saddle point）。

式 (27.11)的右半边说，固定 $\boldsymbol{y}^\star$ 时 $\boldsymbol{x}^\star$ 全局最小；左半边说，固定 $\boldsymbol{x}^\star$ 时 $\boldsymbol{y}^\star$ 全局最大。任何一侧单独改变，都不能改善自己的目标。山口的类比在这里到头了：山的形状只有一种，而鞍点还取决于哪个变量要最小化、哪个要最大化。

这个定义比第 10章的鞍点多了分工。那一章的鞍点指 Hessian 不定的驻点，只看函数形状，不问变量的角色。

要把几个相近的概念分开，看图 27.5中的三个二次函数，以及后面一个四次函数。x 是外层变量，y 是内层变量。

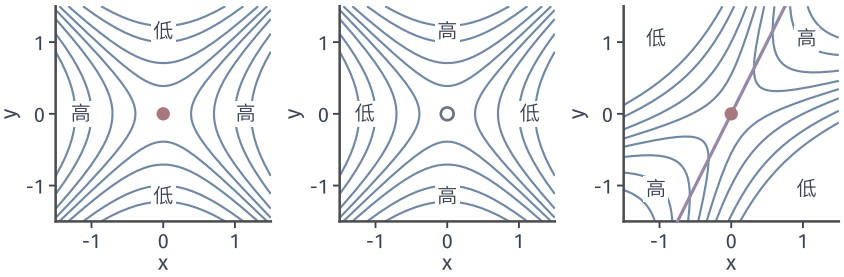


图 27.5 原点都是两侧一阶驻定点，蓝线是等高线，“高”“低”标出函数值的高低区域。(a)$x^2 - y^2$：沿 x 最小、沿 y 最大，红点是全局鞍点。(b)$y^2 - x^2$：形状相同而角色相反，空心点既不是鞍点，也不解决顺序问题。(c)$-\frac{1}{2}x^2 + 2xy - \frac{1}{2}y^2$：紫线是最优响应 $y = 2x$，红点解决顺序问题，却不是鞍点。

(a) 的 $f = x^2 - y^2$ 在全平面满足式 (27.11)，原点是全局鞍点。(b) 的 $f = y^2 - x^2$ 在原点的两个偏导数也都为零，但固定 $y = 0$ 时 $-x^2$ 在 $x = 0$ 处最大，外层变量离开原点反而更好。

(c) 最值得留意。取 $f = -\frac{1}{2}x^2 + 2xy - \frac{1}{2}y^2$，$X = Y = \mathbb{R}$。这个函数在本章后面反复使用。内层关于 y 严格凹，令 $\partial_y f = 2x - y = 0$，得 $y^\star(x) = 2x$。代回得到

$$\phi(x) = -\frac{1}{2}x^2 + 4x^2 - 2x^2 = \frac{3}{2}x^2. \tag{27.12}$$

ϕ 的最小点是 $x = 0$，顺序问题的解是原点，值是 0。可是固定 $y = 0$ 时 $f(x, 0) = -\frac{1}{2}x^2$ 在 $x = 0$ 处最大，式 (27.11)的右半边不成立。对任意 y，$\psi(y) = \inf_x f = -\infty$，所以 $\underline{v} = -\infty < 0 = \bar{v}$。外层在这里不是对 $\boldsymbol{x}$ 最小化固定的 f，它考虑的是 y 会跟着 x 一起变，这个跟随效应把 $-\frac{1}{2}x^2$ 的向下弯曲翻了过来。

局部的版本是把式 (27.11)中的“所有”改成“$(\boldsymbol{x}^\star, \boldsymbol{y}^\star)$ 某个邻域内的所有”，称为**局部鞍点**（local saddle point）。例如在 $X = [-3, 3]$，$Y = [-1, 1]$ 上取

$$f(x, y) = x^2 - \frac{1}{4}x^4 - y^2. \tag{27.13}$$

在原点附近 $x^2 - \frac{1}{4}x^4 \geq 0$，所以原点是局部鞍点。但 $f(3, 0) = 9 - \frac{81}{4} = -11.25 < 0$，外层变量跑远了反而更好，所以原点不是全局鞍点。

概念	要求	例子
两侧一阶驻定	无约束时两个偏梯度为零	图 27.5三个原点
局部鞍点	式 (27.11)在邻域内成立	式 (27.13)的原点
全局鞍点	式 (27.11)在全域成立	$x^2 - y^2$ 的原点
顺序问题的解	$\boldsymbol{x}$ 最小化 ϕ	图 27.5(c) 的原点

表 27.2　四个相近概念的比较。两侧一阶驻定最弱，它不自动解决顺序问题；顺序问题的解也不一定是鞍点。

全局鞍点与两个次序的关系，由下面的定理给出。

定理 27.7　鞍点与最值相等　设 $\boldsymbol{x}^\star \in \boldsymbol{X}$，$\boldsymbol{y}^\star \in \boldsymbol{Y}$。$(\boldsymbol{x}^\star, \boldsymbol{y}^\star)$ 是全局鞍点，当且仅当同时满足

$$\phi(\boldsymbol{x}^\star) = \bar{\upsilon}, \qquad \psi(\boldsymbol{y}^\star) = \underline{\upsilon}, \qquad \bar{\upsilon} = \underline{\upsilon} \in \mathbb{R}. \tag{27.14}$$

此时共同的值等于 $f(\boldsymbol{x}^\star, \boldsymbol{y}^\star)$。

证明　必要性。对式 (27.11)的左半边取 $\boldsymbol{y}$ 的上确界，右半边取 $\boldsymbol{x}$ 的下确界，得到

$$\phi(\boldsymbol{x}^\star) \le f(\boldsymbol{x}^\star, \boldsymbol{y}^\star) \le \psi(\boldsymbol{y}^\star).$$

结合定义，又有

$$\underline{\upsilon} \le \bar{\upsilon} \le \phi(\boldsymbol{x}^\star), \qquad \psi(\boldsymbol{y}^\star) \le \underline{\upsilon}.$$

把这些不等式连起来，就成为一个闭环，其中所有的量都相等。

充分性。由式 (27.14)，$\phi(\boldsymbol{x}^\star) = \psi(\boldsymbol{y}^\star)$ 是有限数。定义给出

$$\psi(\boldsymbol{y}^\star) \le f(\boldsymbol{x}^\star, \boldsymbol{y}^\star) \le \phi(\boldsymbol{x}^\star),$$

所以三者相等。于是对任意 $\boldsymbol{x}, \boldsymbol{y}$，

$$f(\boldsymbol{x}^\star, \boldsymbol{y}) \le \phi(\boldsymbol{x}^\star) = \psi(\boldsymbol{y}^\star) \le f(\boldsymbol{x}, \boldsymbol{y}^\star),$$

中间的值等于 $f(\boldsymbol{x}^\star, \boldsymbol{y}^\star)$，这就是式 (27.11)。 ■

定理说明鞍点集合是一个乘积集合。若 $(\boldsymbol{x}_1, \boldsymbol{y}_1)$ 和 $(\boldsymbol{x}_2, \boldsymbol{y}_2)$ 都是鞍点，式 (27.14)的三条对 $(\boldsymbol{x}_1, \boldsymbol{y}_2)$ 同样成立，所以它也是鞍点，不需要把两侧配对寻找。这与第 18章的 Lagrange 鞍点定理一致，那里的 $\mathcal{L}$ 就是这里的 f。

27.1 极小极大问题
27.2 最坏值函数
27.3 鞍点
27.3.1 最值交换
27.3.2 鞍点间隙
27.4 内层响应法
27.5 下降—上升方法
27.6 校正方向
27.7 结果评价
27.8 本章小结

27.3.1 最值交换

什么条件能让 $\underline{v} = \bar{v}$？先回到图 27.1的代价表，看一个修复办法。两个次序之所以不同，是因为每一方只能选一个端点。设想方案可以按比例组合：把份额 p 投给方案 a，$1-p$ 投给方案 b；扰动也按比例 q 和 $1-q$ 作用，代价按份额加权。

记 $p, q \in [0,1]$，代价为

$$f(p,q) = 3pq + p(1-q) + 2(1-p)(1-q).$$

展开并配方，得到

$$f(p,q) = 4pq - p - 2q + 2 = 4\Big(p - \frac{1}{2}\Big)\Big(q - \frac{1}{4}\Big) + \frac{3}{2}. \tag{27.15}$$

f 关于 q 是线性的，最大值在端点取到，所以

$$\phi(p) = \max\{f(p,0), f(p,1)\} = \max\{2-p, 3p\}.$$

同理，f 关于 p 线性，最小值在端点取到，所以

$$\psi(q) = \min\{f(0,q), f(1,q)\} = \min\{2-2q, 1+2q\}.$$

ϕ 在 $2-p = 3p$ 即 $p = \frac{1}{2}$ 处最小，ψ 在 $2-2q = 1+2q$ 即 $q = \frac{1}{4}$ 处最大，并且

$$\phi\Big(\frac{1}{2}\Big) = \psi\Big(\frac{1}{4}\Big) = \frac{3}{2}.$$

由定理 27.7，$(\frac{1}{2}, \frac{1}{4})$ 是鞍点，见图 27.6。两个次序现在给出同一个值 $\frac{3}{2}$，它落在原来的 1 和 2 之间。允许按比例组合，也就是把问题做成关于各自变量线性的，先后的差别消失了。

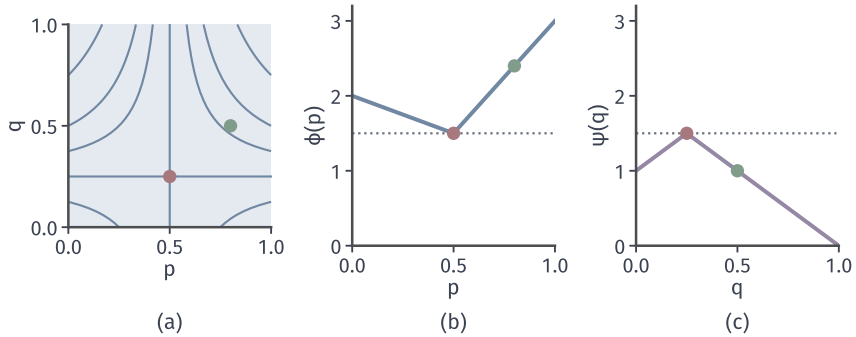


图 27.6 代价表的比例松弛 $f(p,q) = 4(p-\frac{1}{2})(q-\frac{1}{4}) + \frac{3}{2}$。(a) 浅蓝是可行域，蓝线是等高线，穿过红点的十字是值为 $\frac{3}{2}$ 的等高线，红点是鞍点，绿点是候选 $(0.8, 0.5)$。(b) 外层目标 $\phi(p)$，红点是最小点。(c)$\psi(q)$，红点是最大点。点线是共同的值 $\frac{3}{2}$，绿点是候选在两条曲线上的值。

这个例子的结构可以一般化：两个集合都是紧凸集，f 关于 $\boldsymbol{x}$ 凸、关于 $\boldsymbol{y}$ 凹。凸凹性是说，混合之后不会比原来更有利于对面。

定理 27.8　紧集上的极小极大定理　设 $\boldsymbol{X}, \boldsymbol{Y}$ 非空、紧、凸，f 在 $\boldsymbol{X}\times\boldsymbol{Y}$ 上连续；对每个 $\boldsymbol{y}\in\boldsymbol{Y}$，$f(\cdot,\boldsymbol{y})$ 是凸函数；对每个 $\boldsymbol{x}\in\boldsymbol{X}$，$f(\boldsymbol{x},\cdot)$ 是凹函数。则

$$\min_{\boldsymbol{x}\in\boldsymbol{X}}\max_{\boldsymbol{y}\in\boldsymbol{Y}} f(\boldsymbol{x},\boldsymbol{y}) = \max_{\boldsymbol{y}\in\boldsymbol{Y}}\min_{\boldsymbol{x}\in\boldsymbol{X}} f(\boldsymbol{x},\boldsymbol{y}), \tag{27.16}$$

两侧的最值都达到，并且存在全局鞍点。

证明　由式 (27.2)，只需排除 $\underline{v}<\bar{v}$。用反证法，设 $\underline{v}<\bar{v}$，取实数 c 满足 $\underline{v}<c<\bar{v}$。

第一步，把无穷多个 $\boldsymbol{y}$ 化成有限个。对每个 $\boldsymbol{x}\in\boldsymbol{X}$，有 $\phi(\boldsymbol{x})\geq\bar{v}>c$，所以存在 $\boldsymbol{y}$ 使 $f(\boldsymbol{x},\boldsymbol{y})>c$。于是开集族

$$\boldsymbol{U}_{\boldsymbol{y}} = \{\boldsymbol{x}\in\boldsymbol{X} : f(\boldsymbol{x},\boldsymbol{y})>c\},\qquad \boldsymbol{y}\in\boldsymbol{Y}$$

覆盖了 $\boldsymbol{X}$。$\boldsymbol{X}$ 是紧集，存在有限个 $\boldsymbol{y}_1,\dots,\boldsymbol{y}_k$，使每个 $\boldsymbol{x}\in\boldsymbol{X}$ 都至少满足一条 $f(\boldsymbol{x},\boldsymbol{y}_i)>c$。

第二步，用凸性分离出权重。令

$$\boldsymbol{S} = \big\{\boldsymbol{w}\in\mathbb{R}^k : \text{存在 } \boldsymbol{x}\in\boldsymbol{X}, \text{使 } w_i\geq f(\boldsymbol{x},\boldsymbol{y}_i) \text{ 对所有 } i \text{ 成立}\big\}.$$

$\boldsymbol{X}$ 是凸集，每个 $f(\cdot,\boldsymbol{y}_i)$ 是凸函数，所以 $\boldsymbol{S}$ 是凸集。点 $\boldsymbol{c}=(c,\dots,c)$ 不在 $\boldsymbol{S}$ 中，否则某个 $\boldsymbol{x}$ 使所有 $f(\boldsymbol{x},\boldsymbol{y}_i)\leq c$，与第一步矛盾。

第 18章的点与凸集分离引理不要求 $\boldsymbol{S}$ 闭，由它得到 $\boldsymbol{a}\neq\boldsymbol{0}$，使

$$\langle\boldsymbol{a},\boldsymbol{w}\rangle\geq\langle\boldsymbol{a},\boldsymbol{c}\rangle\qquad \text{对所有 } \boldsymbol{w}\in\boldsymbol{S}.$$

$\boldsymbol{S}$ 中的点把任一分量增大后仍在 $\boldsymbol{S}$ 中。若某个 $a_i<0$，让 $w_i\to+\infty$，左端趋于 $-\infty$，矛盾。所以 $\boldsymbol{a}\geq\boldsymbol{0}$，可以归一化为 $\sum_i a_i=1$，此时 $\langle\boldsymbol{a},\boldsymbol{c}\rangle=c$。

对任意 $\boldsymbol{x}\in\boldsymbol{X}$，取 $w_i=f(\boldsymbol{x},\boldsymbol{y}_i)$，得到

$$\sum_{i=1}^{k} a_i f(\boldsymbol{x},\boldsymbol{y}_i)\geq c.$$

第三步，用凹性把有限个 $\boldsymbol{y}_i$ 合成一个。令 $\bar{\boldsymbol{y}} = \sum_i a_i \boldsymbol{y}_i$。$\boldsymbol{Y}$ 是凸集，所以 $\bar{\boldsymbol{y}} \in \boldsymbol{Y}$。$f(\boldsymbol{x}, \cdot)$ 是凹函数，所以对所有 $\boldsymbol{x} \in \boldsymbol{X}$，

$$f(\boldsymbol{x}, \bar{\boldsymbol{y}}) \geq \sum_{i=1}^{k} a_i f(\boldsymbol{x}, \boldsymbol{y}_i) \geq c.$$

于是 $\psi(\bar{\boldsymbol{y}}) \geq c > \underline{v}$，与 $\underline{v}$ 是 ψ 的上确界矛盾。所以 $\underline{v} = \bar{v}$。

最后看达到。由定理 27.3，ϕ 在紧集 $\boldsymbol{X}$ 上连续，最小值达到；对 $-f$ 用同一定理，ψ 在紧集 $\boldsymbol{Y}$ 上连续，最大值达到。取最优点 $\boldsymbol{x}^\star, \boldsymbol{y}^\star$，由定理 27.7，它们组成全局鞍点。 ■

证明里每个条件各有职责。$\boldsymbol{X}$ 紧把无穷多个响应化为有限个；关于 $\boldsymbol{x}$ 的凸性使 $\boldsymbol{S}$ 凸，因而能分离出权重；关于 $\boldsymbol{y}$ 的凹性与 $\boldsymbol{Y}$ 的凸性把“按权重混合的 $\boldsymbol{y}_i$”合成 $\boldsymbol{Y}$ 中的一个点。开头的 $(x-y)^2$ 缺的是最后一条：f 关于 y 是凸的，端点 $y = \pm 1$ 按等权混合的代价是 $x^2 + 1$，而单点 $y = 0$ 的代价只有 x^2，混合无法用一个 y 代替。

放宽紧性时要分别核对　更一般的 Sion 定理只要求其中一个集合紧，把凸凹性放宽为拟凸拟凹，连续性放宽为半连续，结论仍是两个次序的值相等[1]。它的证明需要一套关于水平集连通性的论证，篇幅较长。这里用两个例子说明放宽之后什么会失去。

两个集合都不紧时，值可能不相等。在 $X = Y = [0, \infty)$ 上取

$$f(x, y) = \frac{y - x}{1 + x + y}.$$

由于 $f = -1 + \frac{1+2y}{1+x+y}$，它关于 x 凸；由于 $f = 1 - \frac{1+2x}{1+x+y}$，它关于 y 凹。令 $y \to \infty$ 得 $\phi(x) = 1$，令 $x \to \infty$ 得 $\psi(y) = -1$，所以 $\bar{v} = 1$，$\underline{v} = -1$。这里凸凹性和连续性都有，只是少了紧性，见图 27.7(a)。

值相等也不等于鞍点存在。在 $X = [0, \infty), Y = [0, 1]$ 上取 $f(x, y) = ye^{-x}$，满足 Sion 定理的条件。内层取 $y = 1$，得 $\phi(x) = e^{-x}$，它的下确界是 0，但没有 x 取到；外层令 $x \to \infty$，得 $\psi(y) = 0$。所以 $\bar{v} = \underline{v} = 0$，而没有 x 使 $\phi(x) = 0$，由定理 27.7，鞍点不存在，见图 27.7(b)。

27.1 极小极大问题
27.2 最坏值函数
27.3 鞍点
27.3.1 最值交换
27.3.2 鞍点间隙
27.4 内层响应法
27.5 下降—上升方法
27.6 校正方向
27.7 结果评价
27.8 本章小结

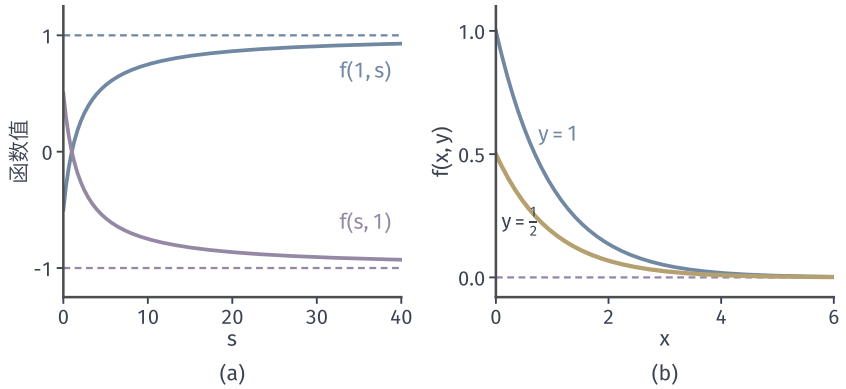


图 27.7 放宽紧性的两种后果。(a)$f=(y-x)/(1+x+y)$ 在 $[0,\infty)^2$ 上：蓝线 $f(1,s)$ 沿 $y=s$ 趋于蓝色虚线 1，紫线 $f(s,1)$ 沿 $x=s$ 趋于紫色虚线 -1，两个次序的值不同。(b)$f=ye^{-x}$：蓝线和黄线分别是 $y=1,\frac{1}{2}$ 时的截线，都趋于紫色虚线 0 而取不到，值相等但没有鞍点。

最值相等是一个关于数的结论。要从中取出一对点，还必须分别核对 ϕ 的最小值和 ψ 的最大值是否达到。

27.3.2 鞍点间隙

有了 ϕ 和 ψ，就能给任何一对可行候选打分。这是第 18章“可行点给上界、乘子给下界”的直接推广。

定义 27.9 鞍点间隙 对 $(\boldsymbol{x},\boldsymbol{y})\in\boldsymbol{X}\times\boldsymbol{Y}$，定义

$$G(\boldsymbol{x},\boldsymbol{y})=\sup_{\boldsymbol{v}\in\boldsymbol{Y}} f(\boldsymbol{x},\boldsymbol{v})-\inf_{\boldsymbol{u}\in\boldsymbol{X}} f(\boldsymbol{u},\boldsymbol{y})=\phi(\boldsymbol{x})-\psi(\boldsymbol{y}), \tag{27.17}$$

称为**鞍点间隙**（saddle gap），其中 $\phi(\boldsymbol{x})=+\infty$ 或 $\psi(\boldsymbol{y})=-\infty$ 时 $G=+\infty$。

间隙度量的是：固定对方，各自还能改善多少，两边加起来。

定理 27.10 间隙是全局证书 对任意 $(\boldsymbol{x},\boldsymbol{y})\in\boldsymbol{X}\times\boldsymbol{Y}$，只要 $G(\boldsymbol{x},\boldsymbol{y})$ 有定义，就有 $G(\boldsymbol{x},\boldsymbol{y})\geq\bar{v}-\underline{v}\geq 0$，并且

$$\phi(\boldsymbol{x})-\bar{v}\leq G(\boldsymbol{x},\boldsymbol{y}),\qquad \underline{v}-\psi(\boldsymbol{y})\leq G(\boldsymbol{x},\boldsymbol{y}). \tag{27.18}$$

当 $G(\boldsymbol{x},\boldsymbol{y})$ 有限时，$G(\boldsymbol{x},\boldsymbol{y})=0$ 当且仅当 $(\boldsymbol{x},\boldsymbol{y})$ 是全局鞍点。

证明　由定义，$\phi(\boldsymbol{x}) \geq \bar{v}$，$\psi(\boldsymbol{y}) \leq \underline{v}$，相减得 $G \geq \bar{v} - \underline{v}$，它由式 (27.2)非负。

式 (27.18)的第一式等价于 $\psi(\boldsymbol{y}) \leq \bar{v}$，它由 $\psi(\boldsymbol{y}) \leq \underline{v} \leq \bar{v}$ 得到。第二式等价于 $\underline{v} \leq \phi(\boldsymbol{x})$，它由 $\underline{v} \leq \bar{v} \leq \phi(\boldsymbol{x})$ 得到。

若 $G = 0$，由上面的不等式，$\phi(\boldsymbol{x}) = \bar{v}$，$\psi(\boldsymbol{y}) = \underline{v}$，且 $\bar{v} = \underline{v}$，由定理 27.7它是全局鞍点。反过来，全局鞍点满足式 (27.14)，相减为零。 ■

式 (27.18)是最有用的部分。它不需要知道 $\bar{v}$，就能说出 $\boldsymbol{x}$ 的最坏值离最优最多差多少。回到比例松弛，取图 27.6的绿点 $(p, q) = (0.8, 0.5)$，算得

$$\phi(0.8) = \max\{1.2, 2.4\} = 2.4, \qquad \psi(0.5) = \min\{1, 2\} = 1.$$

所以

$$G(0.8, 0.5) = 1.4.$$

真实的次优量是 $\phi(0.8) - \frac{3}{2} = 0.9$，确实不超过 1.4。

对 $f = xy$，$X = Y = [-1, 1]$，有

$$\phi(x) = |x|, \qquad \psi(y) = -|y|, \qquad G(x, y) = |x| + |y|. \tag{27.19}$$

这个例子的答案可以直接读出来，后面却会看到，最直接的算法在它上面就会失败。

非紧域上的间隙　把上面的集合换成 $X = Y = \mathbb{R}$，同一个 $f = xy$ 的 $\phi(x)$ 在 $x \neq 0$ 时是 $+\infty$，于是 G 除了原点处处是 $+\infty$。此时 G 虽然没有错，却完全不能区分候选的好坏。

常见的处理是只在一个有界区域 $\boldsymbol{B} = \boldsymbol{B_X} \times \boldsymbol{B_Y}$ 上取极值，其中 $\boldsymbol{B_X} \subseteq \boldsymbol{X}$，$\boldsymbol{B_Y} \subseteq \boldsymbol{Y}$，候选在 $\boldsymbol{B}$ 内，得到

$$G_{\boldsymbol{B}}(\boldsymbol{x}, \boldsymbol{y}) = \sup_{\boldsymbol{v} \in \boldsymbol{B_Y}} f(\boldsymbol{x}, \boldsymbol{v}) - \inf_{\boldsymbol{u} \in \boldsymbol{B_X}} f(\boldsymbol{u}, \boldsymbol{y}). \tag{27.20}$$

称为**限定间隙**（restricted gap）。上确界和下确界的范围变小，所以 $G_{\boldsymbol{B}} \leq G$。它是真实间隙的下估计，小的 $G_{\boldsymbol{B}}$ 不能说明 G 小。

式 (27.13)正好说明这一点。取 $\boldsymbol{B} = [-1, 1] \times [-1, 1]$，候选为原点。在 $\boldsymbol{B}$ 内 $x^2 - \frac{1}{4}x^4 \geq 0$，$-y^2 \leq 0$，所以 $G_{\boldsymbol{B}}(0, 0) = 0$。但在整个 $X = [-3, 3]$ 上，

$$\psi(0) = \min_{|u| \leq 3} \Big(u^2 - \frac{1}{4} u^4 \Big) = -11.25, \qquad \phi(0) = 0.$$

27.1 极小极大问题
27.2 最坏值函数
27.3 鞍点
27.4 内层响应法
27.4.1 精确响应
27.4.2 近似响应
27.5 下降—上升方法
27.6 校正方向
27.7 结果评价
27.8 本章小结

所以真实间隙是 11.25，见图 27.8。局部检验框看不到框外的低谷，零的限定间隙不能当作全局证书。

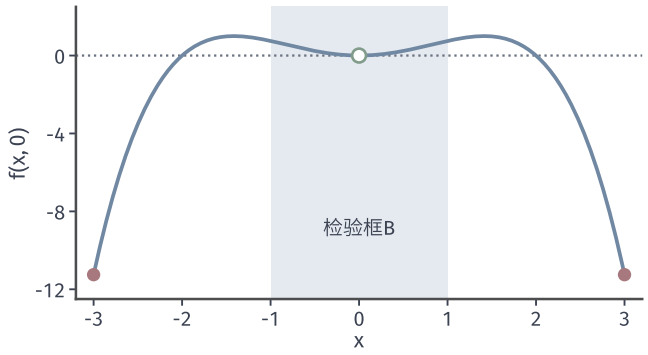


图 27.8 $f(x,y)=x^2-\frac{1}{4}x^4-y^2$ 在 $y=0$ 上的截线，$X=[-3,3]$。浅蓝区域是检验框，框内原点（绿色空心点）的值最小，限定间隙为零。红点是框外的真正最小点，值为 -11.25，真实间隙是 11.25。

凸凹问题里限定间隙的意义强一些。若 $\boldsymbol{B}$ 内含有一个全局鞍点 $(\boldsymbol{x}^\star,\boldsymbol{y}^\star)$，则

$$G_{\boldsymbol{B}}(\boldsymbol{x},\boldsymbol{y})\geq f(\boldsymbol{x},\boldsymbol{y}^\star)-f(\boldsymbol{x}^\star,\boldsymbol{y})\geq 0,$$

所以它至少是一个非负的度量，只要 $\boldsymbol{B}$ 足够大，把解包含在内。这条依赖“$\boldsymbol{B}$ 内含解”这个事实，而这个事实本身需要另外的证据。

27.4 内层响应法

最直接的求解办法是照着决策顺序来：固定当前的 $\boldsymbol{x}$，先求最坏响应，再用值函数的信息更新 $\boldsymbol{x}$。外层用什么算法，前面各章已经讲过，本节只回答两个新问题：内层要解到什么程度，内层的误差怎样传到外层。

图 27.9是整个方法的结构。

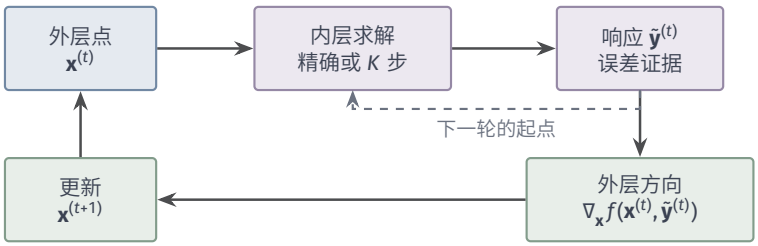


图 27.9 内层响应法的一轮。紫框是内层计算，绿框是外层计算。内层的输出除了响应，还应带有它的误差证据。虚线表示本轮响应作为下一轮内层的起点。

27.1 极小极大问题
27.2 最坏值函数
27.3 鞍点
27.4 内层响应法
27.4.1 精确响应
27.4.2 近似响应
27.5 下降—上升方法
27.6 校正方向
27.7 结果评价
27.8 本章小结

27.4.1 精确响应

主要思想　设内层最优响应唯一且 ϕ 可微。定理 27.4说，算梯度时可以把响应当作常数，所以外层的梯度步就是

$$\boldsymbol{x}^{(t+1)} = P_{\boldsymbol{X}}\Big(\boldsymbol{x}^{(t)} - \alpha \nabla_{\boldsymbol{x}} f\big(\boldsymbol{x}^{(t)}, \boldsymbol{y}^\star(\boldsymbol{x}^{(t)})\big)\Big), \tag{27.21}$$

其中 $\boldsymbol{X}$ 是闭凸集，$P_{\boldsymbol{X}}$ 是第 21章的欧氏投影，$\boldsymbol{X} = \mathbb{R}^n$ 时投影是恒等映射。这就是对 ϕ 做投影梯度法，收敛性由 ϕ 的光滑常数和凸性决定，不需要新的理论。

计算过程　用式 (27.12)的函数演示，$f = -\tfrac{1}{2}x^2 + 2xy - \tfrac{1}{2}y^2$，$X = Y = \mathbb{R}$。

变量

- $x^{(t)}$：外层变量；
- $y^{(t)}$：内层在 $x^{(t)}$ 处的精确响应；
- $g^{(t)}$：外层偏导数；
- $\alpha > 0$：外层步长。

初始化　取 $x^{(0)}$。例中 $x^{(0)} = 1$，步长 $\alpha = \tfrac{1}{6}$，当 $|g^{(t)}| \le 0.4$ 时停止。

每轮更新

1. 解内层，得 $y^{(t)} = y^\star(x^{(t)})$。例中 $y^\star(x) = 2x$，第一轮

$$y^{(0)} = 2.$$

2. 计算外层偏导数 $g^{(t)} = \partial_x f(x^{(t)}, y^{(t)})$。例中 $\partial_x f = -x + 2y$，第一轮

$$g^{(0)} = -1 + 4 = 3.$$

3. 由式 (27.21)更新。例中第一轮

$$x^{(1)} = 1 - \frac{1}{6}\cdot 3 = \frac{1}{2}.$$

第二轮 $y^{(1)} = 1$，$g^{(1)} = \tfrac{3}{2}$，$x^{(2)} = \tfrac{1}{4}$。第三轮 $y^{(2)} = \tfrac{1}{2}$，$g^{(2)} = \tfrac{3}{4}$，$x^{(3)} = \tfrac{1}{8}$。第四轮 $y^{(3)} = \tfrac{1}{4}$，$g^{(3)} = \tfrac{3}{8} \le 0.4$，停止。

最终得到 $x^{(3)} = \tfrac{1}{8}$，最坏值 $\phi(\tfrac{1}{8}) = \tfrac{3}{128}$。例中 $g^{(t)} = \phi'(x^{(t)}) = 3x^{(t)}$，与式 (27.12)的导数相同，这正是定理 27.4的内容。

响应切换时改用非光滑方法 ϕ 有折角时，式 (27.21)里的偏梯度只是一个次梯度，而次梯度不随接近解而变小。设 $f=(x-y)^2$，$Y=[-1,1]$，$x^{(0)}=0.8$，固定步长 $\alpha=0.2$。

$x>0$ 时最坏响应是 $y=-1$，偏导数是 $2(x+1)$；$x<0$ 时最坏响应是 $y=1$，偏导数是 $2(x-1)$。前三步是

$$\begin{aligned} x^{(1)} &= 0.8-0.2\cdot 3.6 = 0.08,\\ x^{(2)} &= 0.08-0.2\cdot 2.16 = -0.352,\\ x^{(3)} &= -0.352+0.2\cdot 2.704 = 0.1888. \end{aligned}$$

迭代很快进入一个周期为 2 的循环。在循环上，$x>0$ 时映射是 $x\mapsto 0.6x-0.4$，$x<0$ 时映射是 $x\mapsto 0.6x+0.4$，解 $a\mapsto -a\mapsto a$ 得到 $a=\frac{1}{4}$。迭代在 $\pm\frac{1}{4}$ 之间来回跳，目标差停在 $(\frac{5}{4})^2-1=0.5625$，见图 27.10中的黄线。

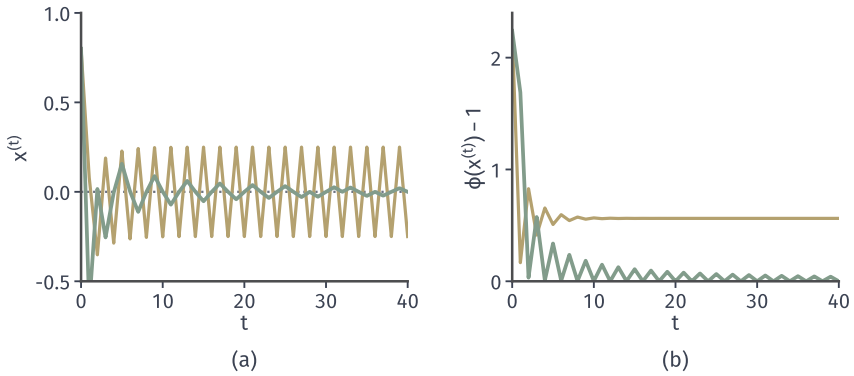


图 27.10 精确响应加次梯度步，$\phi(x)=(|x|+1)^2$，起点 0.8。黄线是固定步长 0.2，绿线是递减步长 $0.4/(t+1)$。(a) 迭代点：黄线进入 $\pm\frac{1}{4}$ 的循环，绿线逐渐收敛到最优解 0。(b) 目标差：黄线停在 0.5625，绿线继续下降。

这是第 11章次梯度法的典型行为，ϕ 是凸函数时那里的结论可以直接使用：有界次梯度下，步长取固定值 $R/(G_{\mathrm{b}}\sqrt{T})$ 时平均点的目标差不超过 $RG_{\mathrm{b}}/\sqrt{T}$，其中 R 是起点到解的距离上界，G_{b} 是次梯度范数上界。要让误差继续减小，步长必须递减。

局部极大不能代替全局最坏响应 定理 27.4要的是全局最优响应。内层不凹时，内层算法通常只能找到局部极大点。看下面的函数，$Y=[-2,2]$：

$$f(x,y)=\frac{1}{2}x^2+xy+y^2-\frac{1}{4}y^4. \tag{27.22}$$

固定 $x=1$，令 $\partial_y f=1+2y-y^3=0$。因式分解得到

$$(y+1)(y^2-y-1)=0,$$

27.1 极小极大问题
27.2 最坏值函数
27.3 鞍点
27.4 内层响应法
27.4.1 精确响应
27.4.2 近似响应
27.5 下降—上升方法
27.6 校正方向
27.7 结果评价
27.8 本章小结

三个根是 $y=-1$，$y=\frac{1+\sqrt{5}}{2}\approx 1.618$，$y=\frac{1-\sqrt{5}}{2}\approx -0.618$。计算得到

$$f(1,-1)=0.25,\qquad f(1,1.618)\approx 3.023,\qquad f(1,-0.618)\approx 0.227.$$

$y=-1$ 是局部极大，$y=1.618$ 是全局极大，$y=-0.618$ 是局部极小，见图 27.11(a)。

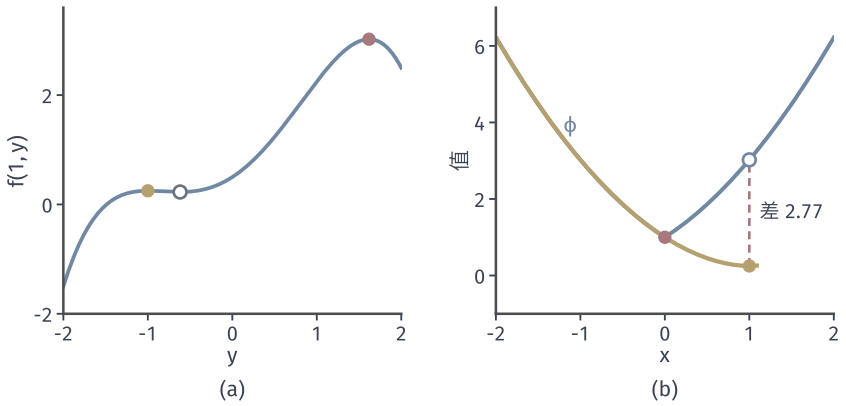


图 27.11 内层不凹的例子，$f=\frac{1}{2}x^2+xy+y^2-\frac{1}{4}y^4$，$Y=[-2,2]$。(a)$x=1$ 时的内层函数：黄点是局部极大，红点是全局极大，空心点是局部极小。(b) 蓝线是真实的 ϕ，红点是外层最优解；黄线是沿局部极大分支算得的值。$x=1$ 处两者相差 2.77，局部分支到 $x\approx 1.089$ 处消失。

假设内层算法从 $y<-0.618$ 的地方起步，它会收敛到 $y=-1$。这一步的代价极大：报告的最坏值是 0.25，真实值是 3.023。更糟的是外层的方向，$\partial_x f=x+y$ 在这个响应处是

$$\partial_x f(1,-1)=0,$$

看起来 $x=1$ 已经驻定。而真实的导数是

$$\phi'(1)=1+1.618=2.618.$$

图 27.11(b) 中，黄线的局部分支一路下降，到 $x=1$ 处还很低，蓝线的真实 ϕ 却在升高。外层最优解其实是 $x=0$，$\phi(0)=1$；局部分支报告的 0.25 甚至低于真正的最优值。

内层关于 $\boldsymbol{y}$ 凹时，这个问题不存在，因为凹函数在凸集上的局部极大就是全局极大。否则，一个响应的“最优”只是相对于找到它的算法而言，后面报告结果时必须说明这一点。

27.4.2 近似响应

实际计算很少精确解内层，算到什么程度够用？先定义内层误差。

固定 $\boldsymbol{x}$，对候选响应 $\tilde{\boldsymbol{y}} \in \boldsymbol{Y}$，称

$$\varepsilon = \phi(\boldsymbol{x}) - f(\boldsymbol{x}, \tilde{\boldsymbol{y}}) \geq 0 \tag{27.23}$$

为内层间隙。用它衡量比用 $\boldsymbol{y}$ 的距离更合适，因为外层真正关心的是最坏值差多少。要把间隙转成外层梯度的误差，需要一座桥，这座桥就是强凹性：顶部越尖，间隙小就越能说明位置近，如同碗越陡，高度差小，水平距离就越小。

下面的条件贯穿本节。设 $\boldsymbol{Y}$ 闭凸；f 的梯度在 $\boldsymbol{X} \times \boldsymbol{Y}$ 上 L-Lipschitz；对每个 $\boldsymbol{x}$，$f(\boldsymbol{x}, \cdot)$ 在 $\boldsymbol{Y}$ 上 μ 强凹，$\mu > 0$，记 $\kappa = L/\mu$。

定理 27.11　内层间隙到外层梯度的传递　在上述条件下，内层响应唯一，记为 $\boldsymbol{y}^\star(\boldsymbol{x})$。对任意 $\tilde{\boldsymbol{y}} \in \boldsymbol{Y}$，

$$\|\tilde{\boldsymbol{y}} - \boldsymbol{y}^\star(\boldsymbol{x})\|_2 \leq \sqrt{\frac{2\varepsilon}{\mu}}. \tag{27.24}$$

进一步，

$$\left\|\nabla_{\boldsymbol{x}} f(\boldsymbol{x}, \tilde{\boldsymbol{y}}) - \nabla_{\boldsymbol{x}} f(\boldsymbol{x}, \boldsymbol{y}^\star(\boldsymbol{x}))\right\|_2 \leq L\sqrt{\frac{2\varepsilon}{\mu}}. \tag{27.25}$$

证明　强凹函数在闭凸集上的最大点存在且唯一，记 $\boldsymbol{y}^\star = \boldsymbol{y}^\star(\boldsymbol{x})$。最优性给出

$$\langle \nabla_{\boldsymbol{y}} f(\boldsymbol{x}, \boldsymbol{y}^\star), \tilde{\boldsymbol{y}} - \boldsymbol{y}^\star \rangle \leq 0.$$

由 μ 强凹的二次上界，

$$f(\boldsymbol{x}, \tilde{\boldsymbol{y}}) \leq f(\boldsymbol{x}, \boldsymbol{y}^\star) + \langle \nabla_{\boldsymbol{y}} f(\boldsymbol{x}, \boldsymbol{y}^\star), \tilde{\boldsymbol{y}} - \boldsymbol{y}^\star \rangle - \frac{\mu}{2}\|\tilde{\boldsymbol{y}} - \boldsymbol{y}^\star\|_2^2.$$

把前一式代入，得到

$$f(\boldsymbol{x}, \tilde{\boldsymbol{y}}) \leq \phi(\boldsymbol{x}) - \frac{\mu}{2}\|\tilde{\boldsymbol{y}} - \boldsymbol{y}^\star\|_2^2.$$

移项就是式 (27.24)。再用 ∇f 的 Lipschitz 性，就得到式 (27.25)。 ■

用 $f = -\frac{1}{2}x^2 + 2xy - \frac{1}{2}y^2$ 在 $x = 1$ 处核对，$\mu = 1$，$y^\star = 2$。取 $\tilde{y} = 1$，内层值和最坏值分别是

$$f(1, 1) = 1, \qquad \phi(1) = \frac{3}{2},$$

所以 $\varepsilon = \frac{1}{2}$。式 (27.24)的右端是 1，真实距离也是 1，等号成立，因为这个内层函数恰好是二次的。

外层偏导数 $\partial_x f = -1 + 2y$ 在 $\tilde{y} = 1$ 处是 1，真实导数是 3，误差是 2，见图 27.12。式 (27.25)用 $L = 3$ 给出的上界是 3，真实误差不超过它。这里交叉项的系数是 2，把 L 换成 $\partial_x f$ 对 y 的 Lipschitz 常数 2，上界就是 2，恰好等于真实误差。

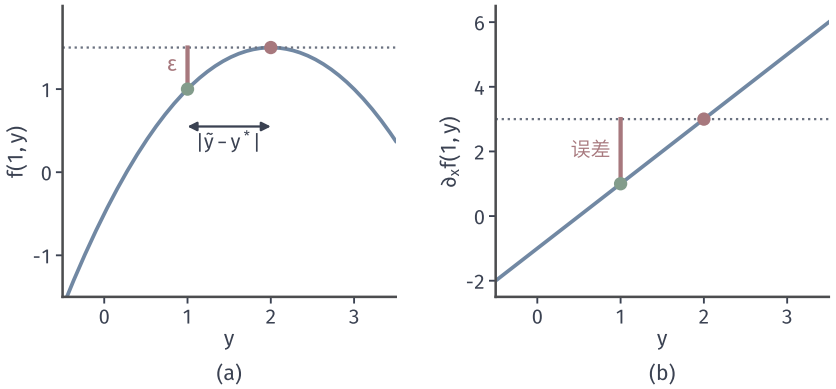


图 27.12 $f = -\frac{1}{2}x^2 + 2xy - \frac{1}{2}y^2$ 在 $x = 1$ 处。(a) 内层函数，红点是最优响应，绿点是候选响应 $\tilde{y} = 1$，红线是内层间隙 $\varepsilon = \frac{1}{2}$，双箭头是响应距离。(b) 外层偏导数关于 y 的直线，红点是真实导数 3，绿点是候选给出的 1，红线是误差。

误差怎样影响外层 梯度带误差时，外层下降还成立吗？先要知道 ϕ 够光滑。下面的引理说明响应随 $\boldsymbol{x}$ 平稳移动，从而 ϕ 可微且梯度 Lipschitz。这里不需要 $\boldsymbol{Y}$ 紧。

引理 27.12 响应的稳定性与 ϕ 的光滑性 在上述条件下，设 $\boldsymbol{X} = \mathbb{R}^n$。则 $\boldsymbol{y}^\star(\cdot)$ 是 κ-Lipschitz 的，ϕ 可微，梯度仍由式 (27.7)的表达式给出，并且 $\nabla\phi$ 是 L_ϕ-Lipschitz 的，其中

$$L_\phi = L(1 + \kappa). \tag{27.26}$$

证明 记 $\boldsymbol{y}_1 = \boldsymbol{y}^\star(\boldsymbol{x}_1)$，$\boldsymbol{y}_2 = \boldsymbol{y}^\star(\boldsymbol{x}_2)$。两个最优性条件给出

$$\langle \nabla_{\boldsymbol{y}} f(\boldsymbol{x}_1, \boldsymbol{y}_1), \boldsymbol{y}_2 - \boldsymbol{y}_1 \rangle \le 0, \qquad \langle \nabla_{\boldsymbol{y}} f(\boldsymbol{x}_2, \boldsymbol{y}_2), \boldsymbol{y}_1 - \boldsymbol{y}_2 \rangle \le 0.$$

$f(\boldsymbol{x}_2, \cdot)$ 的 μ 强凹性给出

$$\mu \|\boldsymbol{y}_1 - \boldsymbol{y}_2\|_2^2 \le \langle \nabla_{\boldsymbol{y}} f(\boldsymbol{x}_2, \boldsymbol{y}_2) - \nabla_{\boldsymbol{y}} f(\boldsymbol{x}_2, \boldsymbol{y}_1), \boldsymbol{y}_1 - \boldsymbol{y}_2 \rangle.$$

右端含 $\nabla_{\boldsymbol{y}} f(\boldsymbol{x}_2, \boldsymbol{y}_2)$ 的项由第二个最优性条件非正，可以丢掉，于是

$$\mu \|\boldsymbol{y}_1 - \boldsymbol{y}_2\|_2^2 \le -\langle \nabla_{\boldsymbol{y}} f(\boldsymbol{x}_2, \boldsymbol{y}_1), \boldsymbol{y}_1 - \boldsymbol{y}_2 \rangle.$$

在内积中加减 $\nabla_{\boldsymbol{y}} f(\boldsymbol{x}_1, \boldsymbol{y}_1)$，并用第一个最优性条件丢掉一项，得到

$$\mu \|\boldsymbol{y}_1 - \boldsymbol{y}_2\|_2^2 \le \langle \nabla_{\boldsymbol{y}} f(\boldsymbol{x}_1, \boldsymbol{y}_1) - \nabla_{\boldsymbol{y}} f(\boldsymbol{x}_2, \boldsymbol{y}_1), \boldsymbol{y}_1 - \boldsymbol{y}_2 \rangle.$$

由 Cauchy–Schwarz 不等式和 Lipschitz 条件，得到

$$\|\boldsymbol{y}_1 - \boldsymbol{y}_2\|_2 \le \kappa \|\boldsymbol{x}_1 - \boldsymbol{x}_2\|_2.$$

再证可微。任取 $\boldsymbol{x}$ 和 $\boldsymbol{d}$，记 $\boldsymbol{y} = \boldsymbol{y}^\star(\boldsymbol{x})$，$\boldsymbol{y}_{\boldsymbol{d}} = \boldsymbol{y}^\star(\boldsymbol{x} + \boldsymbol{d})$，$\boldsymbol{g} = \nabla_{\boldsymbol{x}} f(\boldsymbol{x}, \boldsymbol{y})$。用 $\boldsymbol{y}$ 在 $\boldsymbol{x} + \boldsymbol{d}$ 处的值作下界，并由光滑性，

$$\phi(\boldsymbol{x} + \boldsymbol{d}) - \phi(\boldsymbol{x}) \ge f(\boldsymbol{x} + \boldsymbol{d}, \boldsymbol{y}) - f(\boldsymbol{x}, \boldsymbol{y}) \ge \langle \boldsymbol{g}, \boldsymbol{d} \rangle - \frac{L}{2} \|\boldsymbol{d}\|_2^2.$$

用 $\boldsymbol{y}_{\boldsymbol{d}}$ 作上界，同样由光滑性和响应的 Lipschitz 性，

$$\begin{aligned} \phi(\boldsymbol{x} + \boldsymbol{d}) - \phi(\boldsymbol{x}) &\le f(\boldsymbol{x} + \boldsymbol{d}, \boldsymbol{y}_{\boldsymbol{d}}) - f(\boldsymbol{x}, \boldsymbol{y}_{\boldsymbol{d}}) \\ &\le \langle \nabla_{\boldsymbol{x}} f(\boldsymbol{x}, \boldsymbol{y}_{\boldsymbol{d}}), \boldsymbol{d} \rangle + \frac{L}{2} \|\boldsymbol{d}\|_2^2 \\ &\le \langle \boldsymbol{g}, \boldsymbol{d} \rangle + L\kappa \|\boldsymbol{d}\|_2^2 + \frac{L}{2} \|\boldsymbol{d}\|_2^2. \end{aligned}$$

上下夹逼，得到 ϕ 可微且梯度为 $\boldsymbol{g}$。

最后，由梯度公式和响应的 Lipschitz 性，

$$\|\nabla \phi(\boldsymbol{x}_1) - \nabla \phi(\boldsymbol{x}_2)\|_2 \le L \|\boldsymbol{x}_1 - \boldsymbol{x}_2\|_2 + L \|\boldsymbol{y}_1 - \boldsymbol{y}_2\|_2 \le L(1 + \kappa) \|\boldsymbol{x}_1 - \boldsymbol{x}_2\|_2.$$

■

式 (27.26)说明，ϕ 的光滑常数可能比 f 大 κ 倍。原因是响应会跟着 $\boldsymbol{x}$ 动，κ 越大响应动得越快，外层看到的函数越弯。

定理 27.13　带内层误差的外层下降　在引理 27.12的条件下，设 ϕ 有下界 $\phi_{\inf}$，外层迭代 $\boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} - \alpha \boldsymbol{g}^{(t)}$，其中 $0 < \alpha \le 1/L_\phi$，$\boldsymbol{g}^{(t)}$ 与 $\nabla \phi(\boldsymbol{x}^{(t)})$ 之差的范数不超过 δ。则

$$\min_{0 \le t < T} \|\nabla \phi(\boldsymbol{x}^{(t)})\|_2^2 \le \frac{2(\phi(\boldsymbol{x}^{(0)}) - \phi_{\inf})}{\alpha T} + \delta^2. \tag{27.27}$$

证明　记 $\boldsymbol{x}=\boldsymbol{x}^{(t)}$，$\boldsymbol{g}=\boldsymbol{g}^{(t)}$，$\boldsymbol{e}=\boldsymbol{g}-\nabla\phi(\boldsymbol{x})$。由 L_ϕ-光滑的下降引理和 $\alpha L_\phi \le 1$，

$$\phi(\boldsymbol{x}^{(t+1)}) \le \phi(\boldsymbol{x}) - \alpha\langle \nabla\phi(\boldsymbol{x}), \boldsymbol{g}\rangle + \frac{\alpha}{2}\|\boldsymbol{g}\|_2^2.$$

对任意向量 $\boldsymbol{a},\boldsymbol{b}$ 有恒等式

$$-\langle \boldsymbol{a},\boldsymbol{b}\rangle + \frac{1}{2}\|\boldsymbol{b}\|_2^2 = \frac{1}{2}\|\boldsymbol{b}-\boldsymbol{a}\|_2^2 - \frac{1}{2}\|\boldsymbol{a}\|_2^2.$$

取 $\boldsymbol{a}=\nabla\phi(\boldsymbol{x})$，$\boldsymbol{b}=\boldsymbol{g}$，得到

$$\phi(\boldsymbol{x}^{(t+1)}) \le \phi(\boldsymbol{x}) - \frac{\alpha}{2}\|\nabla\phi(\boldsymbol{x})\|_2^2 + \frac{\alpha}{2}\|\boldsymbol{e}\|_2^2.$$

对 $t=0,\dots,T-1$ 求和，用 $\phi(\boldsymbol{x}^{(T)}) \ge \phi_{\inf}$ 和 $\|\boldsymbol{e}\|_2 \le \delta$，再除以 $\alpha T/2$，左端的平均不小于最小值，即得结论。 ■

式 (27.27)有两项：第一项随 T 下降，第二项是内层误差留下的平台。要让外层梯度小到 ϵ，内层误差 δ 也要到 ϵ 量级。结合式 (27.25)，这要求内层间隙满足 $L\sqrt{2\varepsilon/\mu} \lesssim \epsilon$，即 ε 是 $\mu\epsilon^2/L^2$ 量级。

计算过程　内层用 K 步投影梯度上升，并从上一轮的响应出发，比从头开始省事，因为 $\boldsymbol{x}$ 变化不大时响应也变化不大。仍用 $f=-\frac{1}{2}x^2+2xy-\frac{1}{2}y^2$。

变量

- $x^{(t)}$：外层变量；
- $y^{(t)}$：第 t 轮内层结束后的近似响应；
- K：每轮内层步数；β：内层步长；α：外层步长。

初始化　取 $x^{(0)}$ 和 $y^{(-1)}$。例中 $x^{(0)}=1$，$y^{(-1)}=0$，$K=2$，$\beta=\frac{1}{2}$，$\alpha=\frac{1}{6}$。内层的曲率是 1，步长 $\beta=\frac{1}{2}$ 不超过曲率的倒数。

27.1 极小极大问题
27.2 最坏值函数
27.3 鞍点
27.4 内层响应法
27.5 下降—上升方法
27.5.1 旋转现象
27.5.2 响应速度
27.6 校正方向
27.7 结果评价
27.8 本章小结

每轮更新

1. 从 $y = y^{(t-1)}$ 出发做 K 次内层更新 $y \leftarrow P_Y(y + \beta \partial_y f(x^{(t)}, y))$，得 $y^{(t)}$。例中 $\partial_y f = 2x - y$，第一轮

$$y:\ 0 \to 0 + \frac{1}{2}\cdot 2 = 1 \to 1 + \frac{1}{2}\cdot 1 = 1.5, \qquad y^{(0)} = 1.5.$$

2. 用当前响应计算外层偏导数 $g^{(t)} = \partial_x f(x^{(t)}, y^{(t)})$。例中第一轮

$$g^{(0)} = -1 + 2\cdot 1.5 = 2.$$

3. 更新外层 $x^{(t+1)} = x^{(t)} - \alpha g^{(t)}$。例中第一轮

$$x^{(1)} = 1 - \frac{2}{6} = \frac{2}{3}.$$

第二轮内层从 $y = 1.5$ 出发，目标 $2x^{(1)} = \frac{4}{3}$，两步给出

$$y:\ 1.5 \to 1.41667 \to 1.375, \qquad y^{(1)} = 1.375.$$

外层偏导数是 $g^{(1)} = -\frac{2}{3} + 2.75 \approx 2.0833$，所以 $x^{(2)} \approx 0.3194$。真实导数 $3x^{(1)} = 2$，这一轮的误差约为 0.083。

第一轮的真实导数是 3，误差是 1；第二轮暖启动之后，误差降到 0.083。迭代继续下去，到设定的外层梯度精度为止。这里用 $|g^{(t)}|$ 作判据时要记住，它自身带有内层误差。

一般非凹内层 上面的传递依赖强凹性。没有强凹性时，$\nabla_{\boldsymbol{y}} f$ 很小不说明响应接近最优。式 (27.22)中 $(x, y) = (1, -1)$ 的内层梯度严格为零，内层间隙却是 2.77。此时只从 $\tilde{\boldsymbol{y}}$ 算出的值只是 $\phi(\boldsymbol{x})$ 的下界，真实误差不可知，外层停止时必须说明实际使用的响应证据：用了什么内层算法、多少起点、最后的残差，而不能把 $\nabla_{\boldsymbol{y}} f \approx \mathbf{0}$ 说成“内层已解”。

27.5 下降—上升方法

内层响应法每轮都要解一个优化问题，代价不小。能不能每轮只算一次两侧的梯度，让 $\boldsymbol{x}$ 走一小步下山，同时让 $\boldsymbol{y}$ 走一小步上山？本节研究这个最便宜的做法，它在什么情况下行得通，在什么情况下行不通。

主要思想 设 $\boldsymbol{X}, \boldsymbol{Y}$ 是闭凸集，f 可微。不再要求内层解到最优，而是让 $\boldsymbol{y}$ 只沿内层目标的梯度走一步，$\boldsymbol{x}$ 沿外层方向走一步。这样的方法称为**梯度下降—上升**（gradient descent–ascent，GDA）。

两个偏梯度都在旧点计算，称为同时更新：

$$\begin{aligned} \boldsymbol{x}^{(t+1)} &= P_{\boldsymbol{X}}\big(\boldsymbol{x}^{(t)} - \alpha \nabla_{\boldsymbol{x}} f(\boldsymbol{x}^{(t)}, \boldsymbol{y}^{(t)})\big), \\ \boldsymbol{y}^{(t+1)} &= P_{\boldsymbol{Y}}\big(\boldsymbol{y}^{(t)} + \beta \nabla_{\boldsymbol{y}} f(\boldsymbol{x}^{(t)}, \boldsymbol{y}^{(t)})\big). \end{aligned} \tag{27.28}$$

先更新 $\boldsymbol{x}$，再用新的 $\boldsymbol{x}$ 算 $\boldsymbol{y}$ 的梯度，称为先后更新：

$$\begin{aligned} \boldsymbol{x}^{(t+1)} &= P_{\boldsymbol{X}}\big(\boldsymbol{x}^{(t)} - \alpha \nabla_{\boldsymbol{x}} f(\boldsymbol{x}^{(t)}, \boldsymbol{y}^{(t)})\big), \\ \boldsymbol{y}^{(t+1)} &= P_{\boldsymbol{Y}}\big(\boldsymbol{y}^{(t)} + \beta \nabla_{\boldsymbol{y}} f(\boldsymbol{x}^{(t+1)}, \boldsymbol{y}^{(t)})\big). \end{aligned} \tag{27.29}$$

两式只有第二行里 $\boldsymbol{x}$ 的上标不同，却是不同的递推，下面的例子里轨迹的性质也不同。比较时必须说明用的是哪一种。

计算过程　用 $f(x,y) = xy$，$X = Y = \mathbb{R}$，唯一鞍点是原点。

变量

- $x^{(t)}, y^{(t)}$：两组变量；
- $\alpha, \beta > 0$：两侧步长。

初始化　取 $(x^{(0)}, y^{(0)})$。例中 $(x^{(0)}, y^{(0)}) = (1, 0)$，$\alpha = \beta = \frac{1}{2}$。

每轮更新

1. 计算两个偏导数。例中 $\partial_x f = y$，$\partial_y f = x$。
2. 按式 (27.28)或式 (27.29)更新。例中同时更新的第一轮

$$x^{(1)} = 1 - \frac{1}{2}\cdot 0 = 1, \qquad y^{(1)} = 0 + \frac{1}{2}\cdot 1 = \frac{1}{2}.$$

第二轮、第三轮分别得到

$$(x^{(2)}, y^{(2)}) = (0.75, 1), \qquad (x^{(3)}, y^{(3)}) = (0.25, 1.375).$$

3. 先后更新的第一轮结果相同，因为 $y^{(0)} = 0$ 时 x 不动。第二轮和第三轮分别是

$$(x^{(2)}, y^{(2)}) = (0.75, 0.875), \qquad (x^{(3)}, y^{(3)}) = (0.3125, 1.03125).$$

通常的结束条件是步数达到上限，或残差小于容差。例中距离鞍点的平方，同时更新依次为 $1, 1.25, 1.5625, 1.953$，每轮乘以 1.25；先后更新依次

27.1 极小极大问题
27.2 最坏值函数
27.3 鞍点
27.4 内层响应法
27.5 下降—上升方法
27.5.1 旋转现象
27.5.2 响应速度
27.6 校正方向
27.7 结果评价
27.8 本章小结

为 $1, 1.25, 1.3281, 1.161$，有界地上下波动。最终两种更新都没有接近鞍点。下一小节解释原因。

27.5.1 旋转现象

把同时更新用矩阵写出来，记 $\boldsymbol{z} = (x, y)^{\mathsf{T}}$，式 (27.28)成为

$$\boldsymbol{z}^{(t+1)} = \begin{pmatrix} 1 & -\alpha \\ \alpha & 1 \end{pmatrix} \boldsymbol{z}^{(t)}. \tag{27.30}$$

这个矩阵是一个旋转矩阵乘以 $\sqrt{1+\alpha^2}$。两列互相正交，长度都是 $\sqrt{1+\alpha^2}$，所以

$$\|\boldsymbol{z}^{(t+1)}\|_2^2 = (1+\alpha^2)\|\boldsymbol{z}^{(t)}\|_2^2. \tag{27.31}$$

对任何固定的 $\alpha > 0$，距离都按几何级数增长。$\alpha = \frac{1}{2}$ 时每轮乘以 1.25，与上面的数字一致。步长取得再小，也只是增长得慢，不会变成收缩。

几何上，迭代方向是 $(-y, x)$，它和位置向量 (x, y) 处处垂直，也就是沿着以原点为圆心的圆的切线方向。沿切线走一小段，总是落到更大的圆上。这像绕着一个圆运动的人每走一步都沿当前切线走直线，路线不是回到原圆，而是向外盘旋。连续时间的方程 $\dot{\boldsymbol{z}} = (-y, x)$ 恰好沿圆运动，半径不变；离散化把这个“恰好不靠近”的运动变成了发散。

先后更新的矩阵是

$$\begin{pmatrix} 1 & -\alpha \\ \alpha & 1-\alpha^2 \end{pmatrix},$$

行列式是 1，迹是 $2-\alpha^2$。$0 < \alpha < 2$ 时迹的绝对值小于 2，两个特征值是模为 1 的共轭复数，迭代既不发散也不收敛。

这一点可以用一个守恒量看得更清楚。令 $Q = x^2 + y^2 - \alpha xy$，记 $x^+ = x - \alpha y$，$y^+ = y + \alpha x^+$。先处理含 y^+ 的两项：

$$(y^+)^2 - \alpha x^+ y^+ = y^+(y^+ - \alpha x^+) = y^+ y = y^2 + \alpha x^+ y.$$

再处理剩下的项：

$$(x^+)^2 + \alpha x^+ y = x^+(x^+ + \alpha y) = x^+ x = x^2 - \alpha xy.$$

两式相加，得到

$$(x^+)^2 + (y^+)^2 - \alpha x^+ y^+ = x^2 + y^2 - \alpha xy,$$

所以 Q 沿迭代不变。$0 < \alpha < 2$ 时 Q 是正定二次型，迭代点永远留在同一个椭圆上，既跑不掉也到不了中心。图 27.13(a)(b) 画出了两种轨迹。

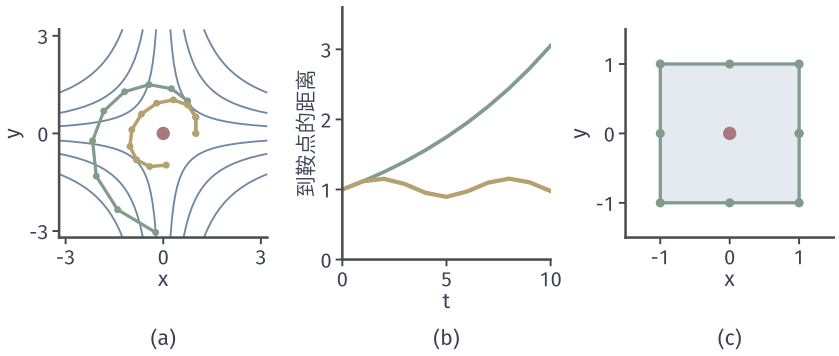


图 27.13 $f = xy$ 上的下降—上升，蓝线是等高线，红点是鞍点。(a)$\alpha = \frac{1}{2}$，起点 $(1,0)$，10 步：绿色是同时更新，向外盘旋；黄色是先后更新，留在椭圆上。(b) 两种更新到鞍点的距离。(c) 盒子 $[-1,1]^2$ 上的投影同时更新，$\alpha = 1$，从 $(1,0)$ 出发，8 步回到起点。

加上约束也不收敛 把迭代限制在盒子里能防止发散，却不能让它停在鞍点。取 $X = Y = [-1,1]$，$\alpha = \beta = 1$，从 $(1,0)$ 出发做投影同时更新，投影就是逐分量截断到 $[-1,1]$。第一步 $x = 1 - 0 = 1$，$y = 0 + 1 = 1$；第二步 $x = 1 - 1 = 0$，$y = 1 + 1 = 2$，截断成 1。继续算下去，得到

$$\begin{aligned}(1,0) &\to (1,1) \to (0,1) \to (-1,1) \to (-1,0) \\ &\to (-1,-1) \to (0,-1) \to (1,-1) \to (1,0).\end{aligned}$$

八步之后回到起点，见图 27.13(c)。由式 (27.19)，循环上的间隙 $|x| + |y|$ 取 1 或 2，永远不小于 1。定理 27.8的条件全部满足，鞍点存在，算法却找不到它。存在性定理回答解在不在，不回答某个算法能否到达。

只看一侧的数不足以判断 图 27.14(a) 是同时更新过程中 $f(x^{(t)}, y^{(t)})$ 的值。从 $t = 2$ 到 $t = 5$，它从 0.75 一路降到 -1.52。如果只看这条线，会以为外层目标在稳步下降，而图 27.14(b) 显示点正在远离解。f 的值本来就该由一侧压低、另一侧抬高，它的升降不说明任何问题。

27.1 极小极大问题
27.2 最坏值函数
27.3 鞍点
27.4 内层响应法
27.5 下降—上升方法
27.5.1 旋转现象
27.5.2 响应速度
27.6 校正方向
27.7 结果评价
27.8 本章小结

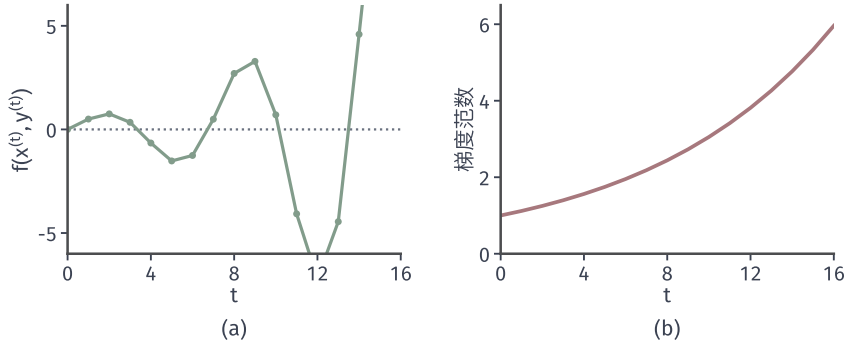


图 27.14 $f = xy$ 上同时更新的监控量，$\alpha = \frac{1}{2}$，起点 $(1, 0)$。(a) 绿线是代价 f 的值，在部分时段连续下降，又在更大的幅度上振荡。(b) 红线是两侧梯度的范数 $\|(y, -x)\|_2$，它等于到鞍点的距离，持续增长。

反过来，梯度为零也说明不了稳定。对 $f = xy$，原点两侧梯度都为零，而且原点就是解，迭代却从任何非零点开始都远离它，一旦有扰动也回不去。对 $f = y^2 - x^2$，原点两侧梯度也为零，但迭代 $x^+ = (1 + 2\alpha)x$，$y^+ = (1 + 2\alpha)y$ 从原点附近往外推，原点又不是解。所以驻定只回答“这个点本身怎样”，不回答“迭代会不会留在它附近”，后者要看迭代映射的线性化。

27.5.2 响应速度

$f = xy$ 没有内层曲率，$\boldsymbol{y}$ 没有自己想去的位置。内层有强凹性时，$\boldsymbol{y}$ 就有一个目标 $\boldsymbol{y}^\star(\boldsymbol{x})$，问题变成：$\boldsymbol{y}$ 能否跟上这个随 $\boldsymbol{x}$ 移动的目标？

继续用 $f = -\frac{1}{2}x^2 + 2xy - \frac{1}{2}y^2$，最优响应是 $y = 2x$，原点是顺序问题的解。令 $\beta = r\alpha$，r 是两侧步长之比。迭代 $\boldsymbol{z}^+ = (\boldsymbol{I} - \alpha \boldsymbol{J}_r)\boldsymbol{z}$ 的矩阵是

$$\boldsymbol{J}_r = \begin{pmatrix} -1 & 2 \\ -2r & r \end{pmatrix}. \tag{27.32}$$

$\boldsymbol{J}_r$ 的迹是 $r-1$，行列式是 $3r$。当 $1 < r < 13$ 时，判别式 $(r-1)^2 - 12r < 0$，两个特征值是共轭复数 λ，满足 $\operatorname{Re}\lambda = \frac{r-1}{2}$，$|\lambda|^2 = 3r$。迭代的模平方是

$$|1 - \alpha\lambda|^2 = 1 - \alpha(r-1) + 3r\alpha^2.$$

这个量小于 1，当且仅当

$$0 < \alpha < \frac{r-1}{3r}. \tag{27.33}$$

$r=1$ 时模平方是 $1+3\alpha^2>1$，任何步长都发散。$r<1$ 时两个特征值的实部为负，$|1-\alpha\lambda|>1$，同样发散。$r=4$ 时条件是 $\alpha<\frac{1}{4}$，例如 $\alpha=0.1$ 时模平方是 0.82。两种选择用同样的 α，差别只在 y 走得快不快，见图 27.15。

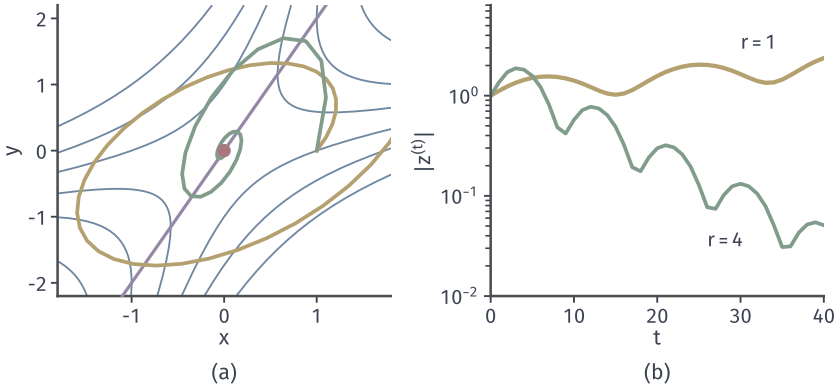


图 27.15 $f=-\frac{1}{2}x^2+2xy-\frac{1}{2}y^2$ 上的同时更新，$\alpha=0.1$，起点 $(1,0)$，40 步。蓝线是等高线，紫线是最优响应 $y=2x$，红点是解。黄线 $r=1$，两侧同速，y 跟不上 x，轨迹向外盘旋。绿线 $r=4$，y 走得快，轨迹贴着紫线向解收敛。(b) 到解的距离。

r 的门槛来自 f 的结构。$\partial_x^2 f=-1$ 是外层变量的负曲率，$\partial_y^2 f=-1$ 是内层变量提供的强凹性。外层独自运动时是往外推的，只有 y 足够快地跟上 $y=2x$，外层才看得到 $\phi''=3>0$ 的正曲率。y 落后时，外层感受到的是 f 在旧 y 上的负曲率，于是被推开。

跟踪误差的递推 一般情形可以用跟踪误差来刻画这种竞赛。沿用第 27.4.2节的条件，记跟踪误差为

$$e_t=\|\boldsymbol{y}^{(t)}-\boldsymbol{y}^\star(\boldsymbol{x}^{(t)})\|_2. \tag{27.34}$$

第 21章证明过：μ 强凸、L-光滑的函数上，步长为 $1/L$ 的投影梯度法把到解的距离至少缩小到 $\rho=\sqrt{1-\mu/L}$ 倍。把它用到凸函数 $-f(\boldsymbol{x},\cdot)$ 上。

引理 27.14 跟踪误差的递推 设 $\boldsymbol{x}^{(t+1)}$ 已经算出，从 $\boldsymbol{y}^{(t)}$ 出发在 $f(\boldsymbol{x}^{(t+1)},\cdot)$ 上做 K 步步长 $1/L$ 的投影梯度上升，得到 $\boldsymbol{y}^{(t+1)}$。则

$$e_{t+1}\le\rho^K\big(e_t+\kappa\|\boldsymbol{x}^{(t+1)}-\boldsymbol{x}^{(t)}\|_2\big). \tag{27.35}$$

27.1 极小极大问题
27.2 最坏值函数
27.3 鞍点
27.4 内层响应法
27.5 下降—上升方法
27.6 校正方向
27.6.1 外梯度法
27.6.2 乐观梯度法
27.7 结果评价
27.8 本章小结

证明 K 步投影梯度上升的收缩给出

$$e_{t+1} \le \rho^K \|\boldsymbol{y}^{(t)} - \boldsymbol{y}^\star(\boldsymbol{x}^{(t+1)})\|_2.$$

用三角不等式，并由引理 27.12的 κ-Lipschitz 性，

$$\|\boldsymbol{y}^{(t)} - \boldsymbol{y}^\star(\boldsymbol{x}^{(t+1)})\|_2 \le e_t + \kappa \|\boldsymbol{x}^{(t+1)} - \boldsymbol{x}^{(t)}\|_2.$$

两式合起来即得。 ■

式 (27.35)里，ρ^K 是内层追赶的速度，$\kappa\|\boldsymbol{x}^{(t+1)} - \boldsymbol{x}^{(t)}\|_2$ 是目标跑开的距离。要跟得上，有两种办法：增加 K，或者减小外层步长。

取 $K = 1$，看外层步长要小到什么程度。设每步外层移动量是 $\alpha\|\boldsymbol{g}\|_2$，$\rho \approx 1 - \frac{1}{2\kappa}$。递推的稳态是

$$e_\infty \approx \frac{\kappa\alpha\|\boldsymbol{g}\|_2}{1-\rho} \approx 2\kappa^2\alpha\|\boldsymbol{g}\|_2.$$

外层梯度的误差约为 Le_∞。要让它不超过 $\frac{1}{2}\|\boldsymbol{g}\|_2$，需要 $\alpha \lesssim \frac{1}{4\kappa^2 L}$，也就是 α/β 是 $1/\kappa^2$ 量级。这个推算只是说明量级，不是证明。完整的结论要把式 (27.35)和定理 27.13放进同一个势函数，得到的是非凸—强凹问题上求 ϕ 的 ϵ 驻定点需要 $O(\kappa^2/\epsilon^2)$ 量级的梯度读取。该证明篇幅较长，读者可查阅双时间尺度下降—上升的专门分析。

理论的步长是保守的。上例 $L = 3$，$\kappa = 3$，上述量级给出的 α 约为 $\frac{1}{108}$，而取 $\beta = \frac{1}{3}$ 时由式 (27.33)可算出实际的稳定范围到 $\alpha < \frac{1}{6}$。保证覆盖的是一个函数类中最差的情形，这与第 6章步长的保守取法一样。

非凸—非凹情形 以上依赖强凹性带来的 κ-Lipschitz 响应。式 (27.22)中最优响应在 $x = 0$ 处从 $-\sqrt{2}$ 跳到 $\sqrt{2}$，没有任何 Lipschitz 常数，内层再快也不能平稳地跟踪。此时必须分别说明三件事：用的是什么步长组合，内层响应求到了什么程度，所报告的驻定概念是什么，第 27.7节回到这些问题。一般非凸—非凹问题上，下降—上升可能循环，也可能发散，没有与上面同类的保证。

27.6 校正方向

上一节的失败发生在凸凹问题上，而且鞍点存在。所以问题不在问题本身，在迭代格式。本节先把鞍点条件写成统一的形式，看清旋转是从哪里来的，再修改迭代，用另一处的方向校正当前一步。

变分不等式形式　把两组变量合并，记 $\boldsymbol{z}=(\boldsymbol{x},\boldsymbol{y})$，$\boldsymbol{Z}=\boldsymbol{X}\times\boldsymbol{Y}$，定义

$$\boldsymbol{F}(\boldsymbol{z})=\begin{pmatrix}\nabla_{\boldsymbol{x}} f(\boldsymbol{x},\boldsymbol{y})\\ -\nabla_{\boldsymbol{y}} f(\boldsymbol{x},\boldsymbol{y})\end{pmatrix}. \tag{27.36}$$

两侧步长相同时，同时更新就是

$$\boldsymbol{z}^{+}=P_{\boldsymbol{Z}}\big(\boldsymbol{z}-\alpha\boldsymbol{F}(\boldsymbol{z})\big).$$

它和投影梯度法外形一样，但 $\boldsymbol{F}$ 一般不是任何函数的梯度。鞍点条件也能用 $\boldsymbol{F}$ 写出来，这个写法就是第 17章见过的变分不等式。

定理 27.15　鞍点的变分不等式刻画　设 $\boldsymbol{X},\boldsymbol{Y}$ 非空闭凸，f 在含 $\boldsymbol{Z}$ 的开集上可微，关于 $\boldsymbol{x}$ 凸，关于 $\boldsymbol{y}$ 凹。则 $\boldsymbol{z}^{\star}\in\boldsymbol{Z}$ 是全局鞍点，当且仅当

$$\langle \boldsymbol{F}(\boldsymbol{z}^{\star}),\boldsymbol{z}-\boldsymbol{z}^{\star}\rangle\geq 0 \qquad \text{对所有 } \boldsymbol{z}\in\boldsymbol{Z}. \tag{27.37}$$

证明　记 $\boldsymbol{z}^{\star}=(\boldsymbol{x}^{\star},\boldsymbol{y}^{\star})$。设它是鞍点。$\boldsymbol{x}^{\star}$ 在凸集 $\boldsymbol{X}$ 上最小化可微凸函数 $f(\cdot,\boldsymbol{y}^{\star})$，一阶条件给出

$$\langle \nabla_{\boldsymbol{x}} f(\boldsymbol{z}^{\star}),\boldsymbol{x}-\boldsymbol{x}^{\star}\rangle\geq 0.$$

$\boldsymbol{y}^{\star}$ 在 $\boldsymbol{Y}$ 上最大化凹函数 $f(\boldsymbol{x}^{\star},\cdot)$，一阶条件给出

$$\langle -\nabla_{\boldsymbol{y}} f(\boldsymbol{z}^{\star}),\boldsymbol{y}-\boldsymbol{y}^{\star}\rangle\geq 0.$$

两式相加即为式 (27.37)。

反过来，在式 (27.37)中取 $\boldsymbol{z}=(\boldsymbol{x},\boldsymbol{y}^{\star})$，得到上面第一式，由凸性，$\boldsymbol{x}^{\star}$ 是 $f(\cdot,\boldsymbol{y}^{\star})$ 的全局最小点。取 $\boldsymbol{z}=(\boldsymbol{x}^{\star},\boldsymbol{y})$，得到第二式，由凹性，$\boldsymbol{y}^{\star}$ 是 $f(\boldsymbol{x}^{\star},\cdot)$ 的全局最大点。这就是式 (27.11)。 ■

式 (27.37)的几何含义是，从 $\boldsymbol{z}^{\star}$ 看向任何可行方向，它与 $\boldsymbol{F}(\boldsymbol{z}^{\star})$ 的夹角都不超过直角，见图 27.16。

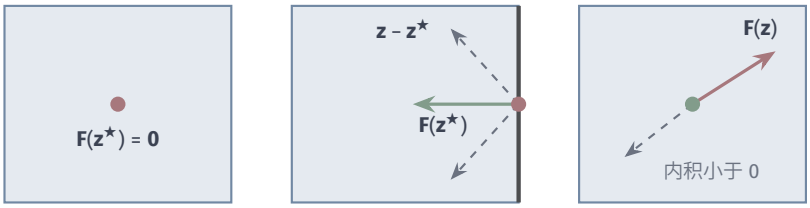


图 27.16　变分不等式的几何。浅蓝矩形是 $\boldsymbol{Z}$。(a) 解在内部时 $\boldsymbol{F}(\boldsymbol{z}^\star)=\boldsymbol{0}$。(b) 解在边界（深灰粗线）上时 $\boldsymbol{F}(\boldsymbol{z}^\star)$ 指向内部，虚线表示的可行方向 $\boldsymbol{z}-\boldsymbol{z}^\star$ 都与它成锐角。(c) 绿点不是解，存在可行方向与红色的 $\boldsymbol{F}(\boldsymbol{z})$ 内积为负。

$\boldsymbol{F}$ 的性质由凸凹性决定。

引理 27.16　单调性　在定理 27.15的条件下，$\boldsymbol{F}$ 是单调算子（monotone operator），即对任意 $\boldsymbol{z}_1,\boldsymbol{z}_2\in\boldsymbol{Z}$，

$$\langle \boldsymbol{F}(\boldsymbol{z}_1)-\boldsymbol{F}(\boldsymbol{z}_2),\boldsymbol{z}_1-\boldsymbol{z}_2\rangle\geq 0. \tag{27.38}$$

证明　记 $\boldsymbol{z}_i=(\boldsymbol{x}_i,\boldsymbol{y}_i)$。由 $f(\cdot,\boldsymbol{y}_1)$ 和 $f(\cdot,\boldsymbol{y}_2)$ 的凸性，

$$f(\boldsymbol{x}_2,\boldsymbol{y}_1)\geq f(\boldsymbol{x}_1,\boldsymbol{y}_1)+\langle\nabla_{\boldsymbol{x}}f(\boldsymbol{z}_1),\boldsymbol{x}_2-\boldsymbol{x}_1\rangle,$$
$$f(\boldsymbol{x}_1,\boldsymbol{y}_2)\geq f(\boldsymbol{x}_2,\boldsymbol{y}_2)+\langle\nabla_{\boldsymbol{x}}f(\boldsymbol{z}_2),\boldsymbol{x}_1-\boldsymbol{x}_2\rangle.$$

由 $f(\boldsymbol{x}_1,\cdot)$ 和 $f(\boldsymbol{x}_2,\cdot)$ 的凹性，

$$f(\boldsymbol{x}_1,\boldsymbol{y}_2)\leq f(\boldsymbol{x}_1,\boldsymbol{y}_1)+\langle\nabla_{\boldsymbol{y}}f(\boldsymbol{z}_1),\boldsymbol{y}_2-\boldsymbol{y}_1\rangle,$$
$$f(\boldsymbol{x}_2,\boldsymbol{y}_1)\leq f(\boldsymbol{x}_2,\boldsymbol{y}_2)+\langle\nabla_{\boldsymbol{y}}f(\boldsymbol{z}_2),\boldsymbol{y}_1-\boldsymbol{y}_2\rangle.$$

把四个不等式相加，函数值全部相消，整理即得式 (27.38)。 ■

单调是梯度单调的推广，f 是凸函数时 ∇f 单调。差别在于 $\boldsymbol{F}$ 的 Jacobian 不对称。f 二阶可微时，

$$\boldsymbol{J}=\begin{pmatrix}\nabla^2_{\boldsymbol{xx}}f & \nabla^2_{\boldsymbol{xy}}f\\ -\nabla^2_{\boldsymbol{yx}}f & -\nabla^2_{\boldsymbol{yy}}f\end{pmatrix}.$$

对角块由凸凹性是半正定的，贡献朝向解的收缩。非对角块反对称，贡献的是旋转，它对 $\langle\boldsymbol{F}(\boldsymbol{z})-\boldsymbol{F}(\boldsymbol{z}'),\boldsymbol{z}-\boldsymbol{z}'\rangle$ 的贡献恰好是零。$f=xy$ 时对角块全是零，$\boldsymbol{J}$ 只剩反对称部分，所以 $\langle\boldsymbol{F}(\boldsymbol{z}),\boldsymbol{z}\rangle=0$。单调性在这里只说明方向不朝外，并不提供任何朝向解的分量，这就是旋转现象的代数来源。

27.1 极小极大问题
27.2 最坏值函数
27.3 鞍点
27.4 内层响应法
27.5 下降—上升方法
27.6 校正方向
27.6.1 外梯度法
27.6.2 乐观梯度法
27.7 结果评价
27.8 本章小结

校正的想法 旋转场里，当前点的方向用一整步就过时了，走到新位置时场已经转了角度。一个自然的修补是：先试探着走一步，读取试探点处的方向，再回到原来的位置，用这个方向走一步。下面的表把这个想法和几种看起来相近的技巧放在一起。

技巧	改的是什么	对 $f=xy$ 的效果
重球动量	叠加上一步的位移	把切向位移加强，更快发散
乘子法	改目标，加增广项后解内层	需要解子问题
外梯度	方向取自预测点	收缩
乐观梯度	用方向的差分校正	收缩

表 27.3 几种修改迭代或目标的办法。前两种不是校正方向。

重球法是第 6章的单目标加速，叠加的是位置差 $\boldsymbol{z}^{(t)}-\boldsymbol{z}^{(t-1)}$。在 $f=xy$ 上，上一步的位移本身就是切向的，叠加之后向外偏得更多。取 $\alpha=0.2$，动量系数 0.5，迭代的谱半径是 1.125，比不加动量时的 1.020 还大。

第 22章的乘子法也交替更新原变量和乘子，但它在 $\boldsymbol{x}$ 上解一个增广 Lagrange 子问题，增广项改变了目标。校正方向不改 f，只改读取方向的位置，每轮仍只是读取几次方向。

27.6.1 外梯度法

主要思想 **外梯度法**（extragradient method，EG）每轮读取两次方向[2]。先从当前点走一个试探步，读取新方向，再回到当前点，用新方向完成校正：

$$\begin{aligned}\tilde{\boldsymbol{z}}^{(t)}&=P_{\mathcal{Z}}\big(\boldsymbol{z}^{(t)}-\alpha\boldsymbol{F}(\boldsymbol{z}^{(t)})\big),\\ \boldsymbol{z}^{(t+1)}&=P_{\mathcal{Z}}\big(\boldsymbol{z}^{(t)}-\alpha\boldsymbol{F}(\tilde{\boldsymbol{z}}^{(t)})\big).\end{aligned}\tag{27.39}$$

校正步的起点仍是 $\boldsymbol{z}^{(t)}$，只是方向换成了试探点的方向。这和连续做两次普通梯度步不同，后者的第二步从 $\tilde{\boldsymbol{z}}^{(t)}$ 出发。

为什么这样能收缩？看 $f=xy$，$\boldsymbol{F}(x,y)=(y,-x)$。在图 27.17中，从 $\boldsymbol{z}$ 沿切线走到 $\tilde{\boldsymbol{z}}$，那里的方向已经向内转过了一个角度。把这个方向拿回 $\boldsymbol{z}$，迈出的一步就略微朝向圆内，抵消了切线外漂。

[2] G. M. Korpelevich, *The Extragradient Method for Finding Saddle Points and Other Problems* In Ekonomika i Matematicheskie Metody, 1976, vol. 12, pp. 747–756

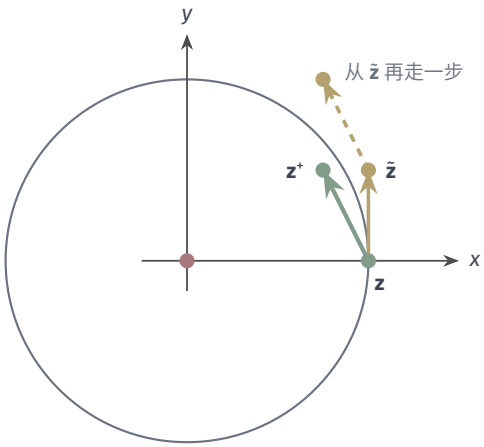


图 27.17 外梯度的一步，$f = xy$，$\alpha = \frac{1}{2}$。灰色圆是过 $\boldsymbol{z} = (1, 0)$ 的等距圆，红点是鞍点。黄色实线箭头走到试探点 $\tilde{\boldsymbol{z}} = (1, 0.5)$，绿色箭头从 $\boldsymbol{z}$ 沿试探点的方向走到 $\boldsymbol{z}^+ = (0.75, 0.5)$，落在圆内。黄色虚线是从试探点再走一步普通梯度步，到 $(0.75, 1)$，落在圆外。

代数上，把 $\boldsymbol{F}(\boldsymbol{z}) = \boldsymbol{A}\boldsymbol{z}$ 代入，$\boldsymbol{A} = \begin{pmatrix} 0 & 1 \\ -1 & 0 \end{pmatrix}$，得到

$$\boldsymbol{z}^+ = \boldsymbol{z} - \alpha\boldsymbol{A}(\boldsymbol{z} - \alpha\boldsymbol{A}\boldsymbol{z}) = \left(\boldsymbol{I} - \alpha\boldsymbol{A} + \alpha^2\boldsymbol{A}^2\right)\boldsymbol{z}.$$

由于 $\boldsymbol{A}^2 = -\boldsymbol{I}$，上式成为 $\boldsymbol{z}^+ = (1 - \alpha^2)\boldsymbol{z} - \alpha\boldsymbol{A}\boldsymbol{z}$。$\boldsymbol{z}$ 与 $\boldsymbol{A}\boldsymbol{z}$ 正交，长度相同，所以

$$\|\boldsymbol{z}^+\|_2^2 = \left(1 - \alpha^2 + \alpha^4\right)\|\boldsymbol{z}\|_2^2. \tag{27.40}$$

$0 < \alpha < 1$ 时这个因子小于 1。多读取的那一次方向，把式 (27.31)里的 $+\alpha^2$ 换成了 $-\alpha^2$，这是二阶项的差别。

计算过程 用 $f = xy$，$X = Y = \mathbb{R}$，投影是恒等映射。

变量

- $\boldsymbol{z}^{(t)} = (x^{(t)}, y^{(t)})$：当前点；
- $\tilde{\boldsymbol{z}}^{(t)}$：试探点；
- $\alpha > 0$：步长。

初始化 取 $\boldsymbol{z}^{(0)} \in \boldsymbol{Z}$。例中 $\boldsymbol{z}^{(0)} = (1, 0)$，$\alpha = \frac{1}{2}$，与上一节相同，便于比较。

每轮更新

1. 在当前点读取方向并试探。例中第一轮

$$\boldsymbol{F}(\boldsymbol{z}^{(0)}) = (0,-1), \qquad \tilde{\boldsymbol{z}}^{(0)} = (1,0) - \frac{1}{2}(0,-1) = (1,0.5).$$

2. 在试探点读取方向，回到当前点校正。例中第一轮

$$\boldsymbol{F}(\tilde{\boldsymbol{z}}^{(0)}) = (0.5,-1), \qquad \boldsymbol{z}^{(1)} = (1,0) - \frac{1}{2}(0.5,-1) = (0.75,0.5).$$

第二轮的试探和校正分别是

$$\tilde{\boldsymbol{z}}^{(1)} = (0.5,0.875), \qquad \boldsymbol{z}^{(2)} = (0.3125,0.75).$$

距离的平方依次为 $1, 0.8125, 0.6602$，每轮乘以 $0.8125 = 1 - \frac{1}{4} + \frac{1}{16}$，与式 (27.40)一致。通常在残差或步数达到要求时结束。最终得到的迭代点向鞍点几何收敛，而同样步长的同时更新每轮乘以 1.25。

平均点的间隙保证　双线性例子的收缩依赖具体的矩阵。一般问题上，外梯度法的保证来自单调性和 Lipschitz 性，对象是试探点的平均

$$\hat{\boldsymbol{z}}_T = (\hat{\boldsymbol{x}}_T, \hat{\boldsymbol{y}}_T) = \frac{1}{T}\sum_{t=0}^{T-1} \tilde{\boldsymbol{z}}^{(t)}.$$

证明用到投影的刻画：$\boldsymbol{p} = P_{\boldsymbol{Z}}(\boldsymbol{w})$ 当且仅当 $\boldsymbol{p} \in \boldsymbol{Z}$，且

$$\langle \boldsymbol{w} - \boldsymbol{p}, \boldsymbol{u} - \boldsymbol{p} \rangle \le 0 \qquad \text{对所有 } \boldsymbol{u} \in \boldsymbol{Z}. \tag{27.41}$$

定理 27.17　外梯度法的平均间隙　设 $\boldsymbol{Z} = \boldsymbol{X} \times \boldsymbol{Y}$ 非空、紧、凸，直径为 D；f 在含 $\boldsymbol{Z}$ 的开集上可微，关于 $\boldsymbol{x}$ 凸，关于 $\boldsymbol{y}$ 凹；$\boldsymbol{F}$ 在 $\boldsymbol{Z}$ 上 L-Lipschitz，$0 < \alpha \le 1/L$。则对任意 $T \ge 1$，

$$G(\hat{\boldsymbol{x}}_T, \hat{\boldsymbol{y}}_T) \le \frac{D^2}{2\alpha T}. \tag{27.42}$$

证明　固定 $\boldsymbol{v} = (\boldsymbol{x}, \boldsymbol{y}) \in \boldsymbol{Z}$，一轮内省略上标，记 $\boldsymbol{z}, \tilde{\boldsymbol{z}}, \boldsymbol{z}^{+}$，$\tilde{\boldsymbol{F}} = \boldsymbol{F}(\tilde{\boldsymbol{z}})$。

对校正步用式 (27.41)，取 $\boldsymbol{w} = \boldsymbol{z} - \alpha\tilde{\boldsymbol{F}}$，$\boldsymbol{p} = \boldsymbol{z}^{+}$，$\boldsymbol{u} = \boldsymbol{v}$，整理得

$$\alpha\langle \tilde{\boldsymbol{F}}, \boldsymbol{z}^{+} - \boldsymbol{v} \rangle \le \langle \boldsymbol{z} - \boldsymbol{z}^{+}, \boldsymbol{z}^{+} - \boldsymbol{v} \rangle.$$

对试探步用式 (27.41)，取 $\boldsymbol{w} = \boldsymbol{z} - \alpha \boldsymbol{F}(\boldsymbol{z})$，$\boldsymbol{p} = \tilde{\boldsymbol{z}}$，$\boldsymbol{u} = \boldsymbol{z}^{+}$，整理得

$$\alpha \langle \boldsymbol{F}(\boldsymbol{z}), \tilde{\boldsymbol{z}} - \boldsymbol{z}^{+} \rangle \le \langle \boldsymbol{z} - \tilde{\boldsymbol{z}}, \tilde{\boldsymbol{z}} - \boldsymbol{z}^{+} \rangle .$$

把要估计的内积拆成三项：

$$\begin{aligned} \alpha \langle \tilde{\boldsymbol{F}}, \tilde{\boldsymbol{z}} - \boldsymbol{v} \rangle &= \alpha \langle \tilde{\boldsymbol{F}}, \boldsymbol{z}^{+} - \boldsymbol{v} \rangle + \alpha \langle \boldsymbol{F}(\boldsymbol{z}), \tilde{\boldsymbol{z}} - \boldsymbol{z}^{+} \rangle \\ &\quad + \alpha \langle \tilde{\boldsymbol{F}} - \boldsymbol{F}(\boldsymbol{z}), \tilde{\boldsymbol{z}} - \boldsymbol{z}^{+} \rangle . \end{aligned}$$

对任意向量有恒等式

$$2 \langle \boldsymbol{a} - \boldsymbol{b}, \boldsymbol{b} - \boldsymbol{c} \rangle = \|\boldsymbol{a} - \boldsymbol{c}\|_2^2 - \|\boldsymbol{a} - \boldsymbol{b}\|_2^2 - \|\boldsymbol{b} - \boldsymbol{c}\|_2^2 .$$

用它处理前两项的上界：

$$\begin{aligned} 2 \langle \boldsymbol{z} - \boldsymbol{z}^{+}, \boldsymbol{z}^{+} - \boldsymbol{v} \rangle &= \|\boldsymbol{z} - \boldsymbol{v}\|_2^2 - \|\boldsymbol{z} - \boldsymbol{z}^{+}\|_2^2 - \|\boldsymbol{z}^{+} - \boldsymbol{v}\|_2^2 , \\ 2 \langle \boldsymbol{z} - \tilde{\boldsymbol{z}}, \tilde{\boldsymbol{z}} - \boldsymbol{z}^{+} \rangle &= \|\boldsymbol{z} - \boldsymbol{z}^{+}\|_2^2 - \|\boldsymbol{z} - \tilde{\boldsymbol{z}}\|_2^2 - \|\tilde{\boldsymbol{z}} - \boldsymbol{z}^{+}\|_2^2 . \end{aligned}$$

第三项由 Cauchy–Schwarz、Lipschitz 条件、$\alpha L \le 1$ 和 $2ab \le a^2 + b^2$ 控制：

$$2\alpha \langle \tilde{\boldsymbol{F}} - \boldsymbol{F}(\boldsymbol{z}), \tilde{\boldsymbol{z}} - \boldsymbol{z}^{+} \rangle \le \|\tilde{\boldsymbol{z}} - \boldsymbol{z}\|_2^2 + \|\tilde{\boldsymbol{z}} - \boldsymbol{z}^{+}\|_2^2 .$$

三项相加，$\|\boldsymbol{z} - \boldsymbol{z}^{+}\|_2^2$、$\|\boldsymbol{z} - \tilde{\boldsymbol{z}}\|_2^2$ 和 $\|\tilde{\boldsymbol{z}} - \boldsymbol{z}^{+}\|_2^2$ 全部相消，得到

$$2\alpha \langle \tilde{\boldsymbol{F}}, \tilde{\boldsymbol{z}} - \boldsymbol{v} \rangle \le \|\boldsymbol{z} - \boldsymbol{v}\|_2^2 - \|\boldsymbol{z}^{+} - \boldsymbol{v}\|_2^2 .$$

对 $t = 0, \dots, T-1$ 求和，右端逐项相消，不超过 $\|\boldsymbol{z}^{(0)} - \boldsymbol{v}\|_2^2 \le D^2$。

再把内积换成函数值。记 $\tilde{\boldsymbol{z}} = (\tilde{\boldsymbol{x}}, \tilde{\boldsymbol{y}})$。由 $f(\cdot, \tilde{\boldsymbol{y}})$ 的凸性和 $f(\tilde{\boldsymbol{x}}, \cdot)$ 的凹性，

$$\begin{aligned} \langle \nabla_{\boldsymbol{x}} f(\tilde{\boldsymbol{z}}), \tilde{\boldsymbol{x}} - \boldsymbol{x} \rangle &\ge f(\tilde{\boldsymbol{x}}, \tilde{\boldsymbol{y}}) - f(\boldsymbol{x}, \tilde{\boldsymbol{y}}) , \\ \langle -\nabla_{\boldsymbol{y}} f(\tilde{\boldsymbol{z}}), \tilde{\boldsymbol{y}} - \boldsymbol{y} \rangle &\ge f(\tilde{\boldsymbol{x}}, \boldsymbol{y}) - f(\tilde{\boldsymbol{x}}, \tilde{\boldsymbol{y}}) . \end{aligned}$$

两式相加，得到

$$\langle \tilde{\boldsymbol{F}}, \tilde{\boldsymbol{z}} - \boldsymbol{v} \rangle \ge f(\tilde{\boldsymbol{x}}, \boldsymbol{y}) - f(\boldsymbol{x}, \tilde{\boldsymbol{y}}) .$$

对 t 取平均。由 Jensen 不等式，$f(\cdot, \boldsymbol{y})$ 凸，所以平均点的值不超过值的平均；$f(\boldsymbol{x}, \cdot)$ 凹，所以平均点的值不低于值的平均。于是

$$f(\hat{\boldsymbol{x}}_T, \boldsymbol{y}) - f(\boldsymbol{x}, \hat{\boldsymbol{y}}_T) \le \frac{D^2}{2\alpha T} .$$

27.1 极小极大问题
27.2 最坏值函数
27.3 鞍点
27.4 内层响应法
27.5 下降—上升方法
27.6 校正方向
27.6.1 外梯度法
27.6.2 乐观梯度法
27.7 结果评价
27.8 本章小结

> 此式对所有 $\boldsymbol{y} \in \boldsymbol{Y}$ 和 $\boldsymbol{x} \in \boldsymbol{X}$ 成立。左端对 $\boldsymbol{y}$ 取最大、对 $\boldsymbol{x}$ 取最小，就是 $G(\hat{\boldsymbol{x}}_T, \hat{\boldsymbol{y}}_T)$。 ■

这里的 $\boldsymbol{Z}$ 需要紧，否则 D 无穷，间隙也可能无穷。证明里真正起作用的是单调性和 Lipschitz 性，不是“多算一次梯度”这个动作本身。所以这个保证不能搬到非凸非凹的问题上。

计算代价方面，每轮要读取两次 $\boldsymbol{F}$、做两次投影，是同时更新的两倍。比较时应按读取次数，而不是轮数。图 27.18按读取次数画出了三种方法，其中紫线是下一小节的方法。

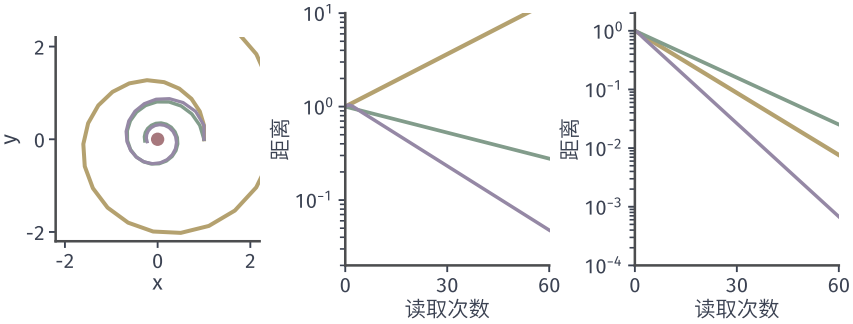


图 27.18 三种方法的比较：黄线同时更新，绿线外梯度，紫线乐观梯度，起点 $(1,0)$。(a)$f = xy$，$\alpha = 0.3$，30 轮的轨迹，红点是解。(b)$f = xy$ 到解的距离，横轴是方向读取次数，外梯度每轮计 2 次。(c)$f = \frac{1}{2}x^2 + 2xy - \frac{1}{2}y^2$，$\alpha = 0.1$，同样按读取次数。

27.6.2 乐观梯度法

主要思想 外梯度法每轮读两次方向，能不能省一次？试探步的目的只是估计“下一步的方向”，而上一轮刚读过的方向已经是一个不错的估计。把试探步里的方向换成上一轮的 $\boldsymbol{F}(\tilde{\boldsymbol{z}}^{(t-1)})$，无约束时得到

$$\tilde{\boldsymbol{z}}^{(t)} = \boldsymbol{z}^{(t)} - \alpha \boldsymbol{F}(\tilde{\boldsymbol{z}}^{(t-1)}), \qquad \boldsymbol{z}^{(t+1)} = \boldsymbol{z}^{(t)} - \alpha \boldsymbol{F}(\tilde{\boldsymbol{z}}^{(t)}).$$

每轮只新读 $\boldsymbol{F}(\tilde{\boldsymbol{z}}^{(t)})$ 一次。

把这个递推写成只含 $\tilde{\boldsymbol{z}}$ 的形式。下一轮的试探点是

$$\tilde{\boldsymbol{z}}^{(t+1)} = \boldsymbol{z}^{(t+1)} - \alpha \boldsymbol{F}(\tilde{\boldsymbol{z}}^{(t)}) = \boldsymbol{z}^{(t)} - 2\alpha \boldsymbol{F}(\tilde{\boldsymbol{z}}^{(t)}).$$

又由试探步，

$$\boldsymbol{z}^{(t)} = \tilde{\boldsymbol{z}}^{(t)} + \alpha \boldsymbol{F}(\tilde{\boldsymbol{z}}^{(t-1)}).$$

代入后把 $\tilde{\boldsymbol{z}}$ 重新记作 $\boldsymbol{z}$，得到**乐观梯度下降—上升**（optimistic gradient descent–ascent，OGDA）：

$$\boldsymbol{z}^{(t+1)} = \boldsymbol{z}^{(t)} - 2\alpha \boldsymbol{F}(\boldsymbol{z}^{(t)}) + \alpha \boldsymbol{F}(\boldsymbol{z}^{(t-1)}). \tag{27.43}$$

把它写成

$$\boldsymbol{z}^{(t+1)} = \boldsymbol{z}^{(t)} - \alpha \boldsymbol{F}(\boldsymbol{z}^{(t)}) - \alpha\big(\boldsymbol{F}(\boldsymbol{z}^{(t)}) - \boldsymbol{F}(\boldsymbol{z}^{(t-1)})\big)$$

就能看出它的含义。括号里是方向场在上一步中的变化量，代表耦合带来的转动。它按当前的变化趋势，把下一步的方向提前校正。“乐观”指相信方向场短期内的变化趋势会延续。它与重球动量的区别在于，重球叠加的是位置的差，这里叠加的是方向的差。

计算过程 用 $f = xy$，$\boldsymbol{F}(x, y) = (y, -x)$。

变量

- $\boldsymbol{z}^{(t)}$：当前点；
- $\boldsymbol{F}^{(t-1)}$：上一轮读到的方向，需要存储；
- $\alpha > 0$：步长。

初始化 取 $\boldsymbol{z}^{(0)}$，并令 $\boldsymbol{z}^{(-1)} = \boldsymbol{z}^{(0)}$，于是第一步就是普通的梯度步。例中 $\boldsymbol{z}^{(0)} = (1, 0)$，$\alpha = 0.2$。

每轮更新

1. 读取当前方向 $\boldsymbol{F}^{(t)} = \boldsymbol{F}(\boldsymbol{z}^{(t)})$。例中第一轮 $\boldsymbol{F}^{(0)} = (0, -1)$，第二轮

$$\boldsymbol{z}^{(1)} = (1, 0.2), \qquad \boldsymbol{F}^{(1)} = (0.2, -1).$$

2. 由式 (27.43)更新，并保存 $\boldsymbol{F}^{(t)}$。例中第二轮

$$\boldsymbol{z}^{(2)} = (1, 0.2) - 0.4(0.2, -1) + 0.2(0, -1) = (0.92, 0.4).$$

继续计算，得到

$$\boldsymbol{z}^{(3)} = (0.8, 0.568), \qquad \boldsymbol{z}^{(4)} = (0.6528, 0.704).$$

距离的平方依次为 $1, 1.04, 1.0064, 0.9626, 0.9218$，第一步因为没有历史而外漂，之后开始收缩。最终得到的迭代点沿螺旋线趋向鞍点，每轮只读一次方向。

双线性情形的稳定性 线性的 $\boldsymbol{F}$ 可以算到底。把 (x, y) 看作复数 $w = x + \mathrm{i}y$，$\boldsymbol{F} = (y, -x)$ 对应 $-\mathrm{i}w$，同时更新就成了 $w^{+} = (1 + \mathrm{i}\alpha)w$，与式 (27.31)一致。式 (27.43)成为二阶递推

$$w^{(t+1)} = (1 + 2\mathrm{i}\alpha)w^{(t)} - \mathrm{i}\alpha w^{(t-1)}.$$

它的特征方程是 $s^2 - (1 + 2\mathrm{i}\alpha)s + \mathrm{i}\alpha = 0$，判别式是

$$(1 + 2\mathrm{i}\alpha)^2 - 4\mathrm{i}\alpha = 1 - 4\alpha^2.$$

$0 < \alpha \le \frac{1}{2}$ 时判别式非负，两根是 $\frac{1}{2}(1 + 2\mathrm{i}\alpha \pm \sqrt{1 - 4\alpha^2})$，模较大的那个满足

$$\rho^2 = \frac{1 + \sqrt{1 - 4\alpha^2}}{2} < 1. \tag{27.44}$$

$\alpha = 0.2$ 时 $\rho^2 \approx 0.958$，上面逐步算出的距离确实以这个比例下降。小步长时 $\rho^2 \approx 1 - \alpha^2$，和外梯度的式 (27.40)同阶。$\alpha > \frac{1}{2}$ 时两根的虚部不同，由 $|s|^2 < 1$ 可得稳定的条件是 $\alpha < 1/\sqrt{3} \approx 0.577$，见图 27.19(a)。外梯度的范围更宽，到 $\alpha < 1$。

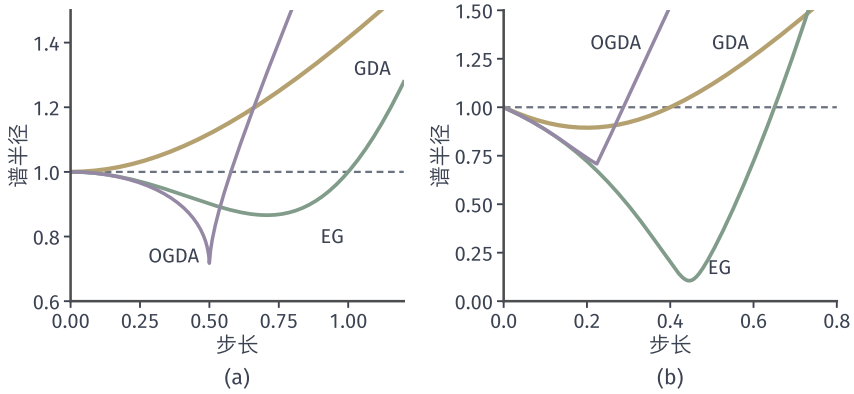


图 27.19 线性 $\boldsymbol{F}$ 上的谱半径与步长的关系。虚线是稳定边界 1。(a)$f = xy$：同时更新（GDA）全在边界之上。外梯度（EG）到 $\alpha < 1$ 稳定，乐观梯度（OGDA）到 $\alpha < 0.577$ 稳定。(b)$f = \frac{1}{2}x^2 + 2xy - \frac{1}{2}y^2$：三种方法都有稳定区间，分别到 0.4、0.65、0.29。

强凸—强凹情形 取 $f = \frac{1}{2}x^2 + 2xy - \frac{1}{2}y^2$，关于 x 强凸，关于 y 强凹，$\mu = 1$。$\boldsymbol{F}$ 是线性的，其矩阵的特征值和 Lipschitz 常数是

$$\lambda = 1 \pm 2\mathrm{i}, \qquad L = |\lambda| = \sqrt{5}.$$

27.1 极小极大问题
27.2 最坏值函数
27.3 鞍点
27.4 内层响应法
27.5 下降—上升方法
27.6 校正方向
27.7 结果评价
27.7.1 误差证据
27.7.2 非凸问题
27.8 本章小结

同时更新和外梯度的每轮因子分别是 $|1-\alpha\lambda|$ 和 $|1-\alpha\lambda+\alpha^2\lambda^2|$。乐观梯度的因子是下面方程模较大的根：

$$s^2-(1-2\alpha\lambda)s-\alpha\lambda=0.$$

方法	$\alpha=0.1$	$\alpha=0.2$	稳定上限
GDA	0.922	0.894	0.400
EG	0.885	0.721	0.651
OGDA	0.885	0.739	0.288

表 27.4 $f=\frac{1}{2}x^2+2xy-\frac{1}{2}y^2$ 上三种方法的每轮收缩因子及步长上限（数值求得）。

表 27.4的因子是按轮计算的，外梯度每轮读两次方向。按读取次数折算，$\alpha=0.1$ 时外梯度相当于每次读取收缩 $\sqrt{0.885}\approx 0.941$，比同时更新的 0.922 还慢，图 27.18(c) 里绿线在黄线之上就是这个原因。外梯度的优势要靠较大的步长才能体现，图 27.19(b) 中它在 $\alpha\approx 0.45$ 处的每轮因子只有 0.105。

对一般的强单调、Lipschitz 算子，已知结论是外梯度和乐观梯度取 α 为 $1/L$ 量级时，每轮收缩因子是 $1-O(\mu/L)$，而同时更新的步长要小到 μ/L^2 量级，因子是 $1-O(\mu^2/L^2)$。证明需要构造带历史项的势函数，篇幅较长，读者可查阅专门的变分不等式著作。

不能直接推广的情形 上述核对都在单调问题上。$f=y^2-x^2$ 的 $\boldsymbol{F}=(-2x,-2y),\lambda=-2$,原点是排斥的：式(27.43)的特征方程 $s^2-(1+4\alpha)s+2\alpha=0$ 在 $s=1$ 处取值 $-2\alpha<0$，所以有一根大于 1。同样的计算也使外梯度的因子 $1+2\alpha+4\alpha^2$ 大于 1。

有约束时还要分清变体。把投影直接加到式 (27.43)上，得到 $P_{\mathcal{Z}}(\boldsymbol{z}^{(t)}-2\alpha\boldsymbol{F}(\boldsymbol{z}^{(t)})+\alpha\boldsymbol{F}(\boldsymbol{z}^{(t-1)}))$；另一种形式保留试探点和校正点两条序列，各做一次投影。无约束时二者等价，有约束时不是同一个递推。

例如在盒子 $[-1,1]^2$ 上，$\boldsymbol{z}^{(0)}=(1,0.9)$，$\alpha=0.4$，$\boldsymbol{F}=(y,-x)$，第一步前者给出 $(0.64,1)$，后者给出 $(0.6,1)$。两种形式的步长条件和分析要分别核对，不能把其中一种的保证直接用到另一种，更不能推广到任意的非凸问题。

27.7 结果评价

算法停下来，交出一对 $(\boldsymbol{x},\boldsymbol{y})$，它有多好？极小极大问题里，$f(\boldsymbol{x}^{(t)},\boldsymbol{y}^{(t)})$ 的升降不能回答这个问题，图 27.14已经表明，两侧的优化方向本来相反，这个数上下波动没有确定的含义。

27.1 极小极大问题
27.2 最坏值函数
27.3 鞍点
27.4 内层响应法
27.5 下降—上升方法
27.6 校正方向
27.7 结果评价
27.7.1 误差证据
27.7.2 非凸问题
27.8 本章小结

所以第一步是说清要评价什么。表 27.5按目标列出相应的证据。

目标	证据	成立前提
全局鞍点	间隙 G 或其有效上界	两侧极值能算或能界
值函数最小	ϕ 的（次）梯度	内层响应可信
局部结构	二阶条件	只在邻域内有意义

表 27.5 评价目标与相应的证据。

27.7.1 误差证据

凸凹问题上最好的证据是间隙 (27.17)。若 ϕ 和 ψ 能直接算出，例如 f 双线性而 $\boldsymbol{X}, \boldsymbol{Y}$ 是单纯形或盒子，内层就是线性函数在顶点上取值，这时间隙是精确的。

平均点与最后一点 定理 27.17保证的是平均点。最后一点可能完全不同。在盒子 $[-1,1]^2$ 上，$f = xy$，$L = 1$，取外梯度法的边界步长 $\alpha = 1$，从 $(1,0)$ 出发。第一轮试探点和校正点是

$$\tilde{\boldsymbol{z}}^{(0)} = (1,1), \qquad \boldsymbol{z}^{(1)} = (1,0) - (1,-1) = (0,1).$$

继续下去，$\boldsymbol{z}^{(t)}$ 依次经过 $(1,0),(0,1),(-1,0),(0,-1)$，每四轮回到起点。试探点依次是四个顶点。

由式 (27.19)，最后一点的间隙恒为 1，没有收敛。而试探点的平均，$T = 1,2,3,4$ 时间隙分别是 $2, 1, \frac{2}{3}, 0$，都不超过定理的上界 $\frac{D^2}{2\alpha T} = \frac{4}{T}$，这里 $D^2 = 8$，见图 27.20。

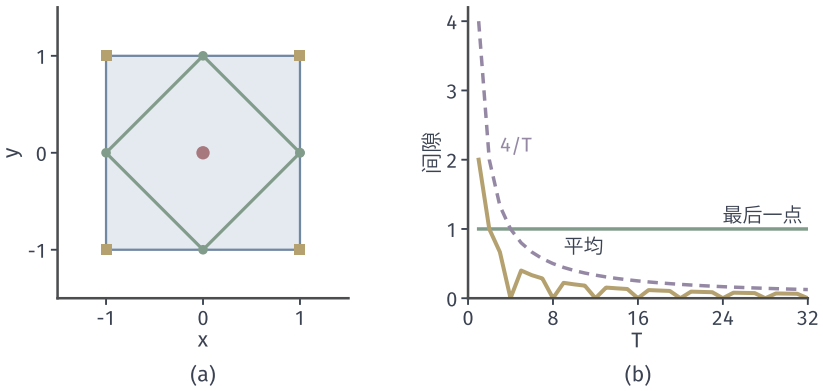


图 27.20 外梯度法取边界步长 $\alpha = 1/L = 1$，$f = xy$，$\boldsymbol{Z} = [-1,1]^2$，起点 $(1,0)$。(a) 绿点是校正点，沿菱形循环；黄色方块是试探点，在四个顶点循环；红点是鞍点。(b) 绿线是最后一点的间隙，恒为 1；黄线是试探点平均的间隙，在每四轮的整数倍处为 0；紫色虚线是上界 $4/T$。

$\alpha < 1/L$ 时可以证明校正点本身收敛到某个鞍点，这个例子的循环出现在边界步长上。最后一点的间隙速率比平均点慢，一般是 $O(1/\sqrt{T})$，证明较长，读者可查阅外梯度法最后迭代分析的专门文献。报告结果时要说清楚输出的是平均点还是最后一点，因为定理的结论只属于它所针对的那一个。

近似内层给出的间隙偏小 ϕ 和 ψ 算不出来时，通常用内层算法分别求一个近似响应 $\tilde{\boldsymbol{y}}$ 和近似外层点 $\tilde{\boldsymbol{x}}$，然后计算

$$\hat{G} = f(\boldsymbol{x}, \tilde{\boldsymbol{y}}) - f(\tilde{\boldsymbol{x}}, \boldsymbol{y}). \tag{27.45}$$

因为 $f(\boldsymbol{x}, \tilde{\boldsymbol{y}}) \le \phi(\boldsymbol{x})$，$f(\tilde{\boldsymbol{x}}, \boldsymbol{y}) \ge \psi(\boldsymbol{y})$，所以 $\hat{G} \le G$。这与第 18章“内层近似的方向”是同一个现象，误差方向正好不利：内层算得越粗糙，估计的间隙越小，算法看起来越好。

取盒子上的 $f = xy$，候选 $(x, y) = (0.4, -0.2)$，由式 (27.19)，真实间隙是 0.6。内层只走一步步长 $\frac{1}{2}$ 的投影梯度：

$$\tilde{y} = -0.2 + \frac{1}{2}\cdot 0.4 = 0, \qquad \tilde{x} = 0.4 - \frac{1}{2}\cdot(-0.2) = 0.5.$$

式 (27.45)给出

$$\hat{G} = f(0.4, 0) - f(0.5, -0.2) = 0 + 0.1 = 0.1.$$

真实间隙 0.6 被低估了六倍。

要得到可靠的上界，必须把内层误差补回去。第 18章由梯度残差得到认证界：μ 强凸函数在 $\tilde{\boldsymbol{x}}$ 处的最小值至少是函数值减去 $\|\nabla\|_2^2/(2\mu)$。把它用到 $-f(\boldsymbol{x}, \cdot)$ 和 $f(\cdot, \boldsymbol{y})$ 上。设 $\boldsymbol{X} = \mathbb{R}^n$，$\boldsymbol{Y} = \mathbb{R}^q$，$f(\boldsymbol{x}, \cdot)$ 是 μ_y 强凹的，$f(\cdot, \boldsymbol{y})$ 是 μ_x 强凸的，则

$$G(\boldsymbol{x}, \boldsymbol{y}) \le \hat{G} + \frac{\|\nabla_{\boldsymbol{y}} f(\boldsymbol{x}, \tilde{\boldsymbol{y}})\|_2^2}{2\mu_y} + \frac{\|\nabla_{\boldsymbol{x}} f(\tilde{\boldsymbol{x}}, \boldsymbol{y})\|_2^2}{2\mu_x}. \tag{27.46}$$

验算一例。$f = \frac{1}{2}x^2 + 2xy - \frac{1}{2}y^2$，$\mu_x = \mu_y = 1$，候选 $(0.2, 0.1)$。真实值由 $\phi(x) = \frac{5}{2}x^2$，$\psi(y) = -\frac{5}{2}y^2$ 算出，

$$G = 0.1 + 0.025 = 0.125.$$

取近似响应 $\tilde{y} = 0.3$，$\tilde{x} = -0.1$，则

$$f(0.2, 0.3) = 0.095, \qquad f(-0.1, 0.1) = -0.02, \qquad \hat{G} = 0.115.$$

27.1 极小极大问题
27.2 最坏值函数
27.3 鞍点
27.4 内层响应法
27.5 下降—上升方法
27.6 校正方向
27.7 结果评价
27.7.1 误差证据
27.7.2 非凸问题
27.8 本章小结

两个残差是 $\partial_y f(0.2, 0.3) = 0.1$，$\partial_x f(-0.1, 0.1) = 0.1$，式 (27.46)的修正量各是 0.005，得到上界

$$0.115 + 0.005 + 0.005 = 0.125.$$

未修正的 $\hat{G}$ 比真实间隙小，修正之后的上界不小于真实间隙。这里等号成立，因为函数恰好是二次的，曲率常数处处精确。

27.7.2 非凸问题

没有凸凹性时，间隙可能恒为正，甚至恒为无穷，图 27.5(c) 的原点就是这样。此时的目标是顺序问题本身，证据要分三层报告，各说明它证明了什么。

值函数的驻定证据 内层强凹时，ϕ 可微，外层的驻定量可以由已知量给出上界。由三角不等式和式 (27.25)，

$$\|\nabla \phi(\boldsymbol{x})\|_2 \le \|\nabla_{\boldsymbol{x}} f(\boldsymbol{x}, \tilde{\boldsymbol{y}})\|_2 + L\sqrt{\frac{2\varepsilon}{\mu}}. \tag{27.47}$$

用 $f = -\frac{1}{2}x^2 + 2xy - \frac{1}{2}y^2$，取 $x = 0.1$，$\tilde{y} = 0.18$。此时外层偏导数是 $-0.1 + 0.36 = 0.26$，内层间隙是 $\frac{1}{2}(0.02)^2 = 0.0002$。交叉系数是 2，第二项是 $2 \cdot 0.02 = 0.04$，上界是 0.30，真实导数 $3x$ 也是 0.30。

式 (27.47)需要 ε 的可靠上界。内层强凹且无约束时，式 (27.46)用到的残差界同样适用，ε 不超过残差平方除以 2μ；有约束时要用相应的对偶界。

响应求解的证据 内层不凹时，ε 一般没有可计算的上界。从多个起点运行内层算法，取最大的值作为 $\phi(\boldsymbol{x})$ 的估计，这是一个越算越大的下界。报告时要写成“在所检查的响应中最坏值是多少”，并说明检查的范围。它不是全局最坏值。式 (27.22)在 $x = 1$ 处，从 $y < -0.618$ 出发只能得到 0.25，从 $y > -0.618$ 出发才能得到 3.023。

局部极小极大条件 不要求全局最坏时，可以问一个更弱的问题：相对于局部的响应分支，当前点是不是极小？下面的二阶充分条件给出一种准确的说法。

定理 27.18　局部极小极大的二阶充分条件　设 f 在 $(\bar{\boldsymbol{x}}, \bar{\boldsymbol{y}})$ 附近二阶连续可微，$\nabla_{\boldsymbol{x}} f$ 和 $\nabla_{\boldsymbol{y}} f$ 在该点为零，$\nabla^2_{\boldsymbol{yy}} f \prec \mathbf{0}$，并且

$$\boldsymbol{S} = \nabla^2_{\boldsymbol{xx}} f - \nabla^2_{\boldsymbol{xy}} f \, (\nabla^2_{\boldsymbol{yy}} f)^{-1} \, \nabla^2_{\boldsymbol{yx}} f \succ \mathbf{0}. \tag{27.48}$$

则存在定义在 $\bar{\boldsymbol{x}}$ 某邻域上的连续可微映射 $\boldsymbol{y}(\boldsymbol{x})$，$\boldsymbol{y}(\bar{\boldsymbol{x}}) = \bar{\boldsymbol{y}}$，使 $\boldsymbol{y}(\boldsymbol{x})$ 是 $f(\boldsymbol{x}, \cdot)$ 的局部极大点，且 $\bar{\boldsymbol{x}}$ 是 $\boldsymbol{x} \mapsto f(\boldsymbol{x}, \boldsymbol{y}(\boldsymbol{x}))$ 的严格局部极小点。称这样的 $(\bar{\boldsymbol{x}}, \bar{\boldsymbol{y}})$ 为**局部极小极大点**（local minimax point）。

证明　方程 $\nabla_{\boldsymbol{y}} f(\boldsymbol{x}, \boldsymbol{y}) = \mathbf{0}$ 在该点关于 $\boldsymbol{y}$ 的 Jacobian 是 $\nabla^2_{\boldsymbol{yy}} f$，可逆。隐函数定理给出连续可微的 $\boldsymbol{y}(\boldsymbol{x})$，其导数是

$$\nabla \boldsymbol{y}(\boldsymbol{x}) = -(\nabla^2_{\boldsymbol{yy}} f)^{-1} \nabla^2_{\boldsymbol{yx}} f.$$

由连续性，$\nabla^2_{\boldsymbol{yy}} f$ 在邻域内保持负定，所以 $\boldsymbol{y}(\boldsymbol{x})$ 是局部极大点。

令 $h(\boldsymbol{x}) = f(\boldsymbol{x}, \boldsymbol{y}(\boldsymbol{x}))$。因为在响应分支上 $\nabla_{\boldsymbol{y}} f = \mathbf{0}$，链式法则只留下关于 $\boldsymbol{x}$ 的偏梯度：

$$\nabla h(\boldsymbol{x}) = \nabla_{\boldsymbol{x}} f(\boldsymbol{x}, \boldsymbol{y}(\boldsymbol{x})).$$

再求一次导，得到

$$\nabla^2 h = \nabla^2_{\boldsymbol{xx}} f + \nabla^2_{\boldsymbol{xy}} f \, \nabla \boldsymbol{y}(\boldsymbol{x}).$$

代入 $\nabla \boldsymbol{y}$ 的表达式，在 $\bar{\boldsymbol{x}}$ 处就是 $\boldsymbol{S}$。又 $\nabla h(\bar{\boldsymbol{x}}) = \mathbf{0}$，$\boldsymbol{S} \succ \mathbf{0}$，由二阶充分条件，$\bar{\boldsymbol{x}}$ 是 h 的严格局部极小点。 ■

对 $f = -\frac{1}{2}x^2 + 2xy - \frac{1}{2}y^2$，$\nabla^2_{yy} f = -1$，$S = -1 - 2 \cdot (-1) \cdot 2 = 3$，恰好是 ϕ''。

这个条件只回答局部响应分支。把式 (27.22)放到 $(1, -1)$ 处，两个偏导数 $x+y$ 和 $x+2y-y^3$ 都是 0，$\partial^2_y f = 2 - 3y^2 = -1 < 0$，$\partial^2_x f = 1$，$\partial_{xy} f = 1$，

$$S = 1 - 1 \cdot (-1) \cdot 1 = 2 > 0.$$

定理的全部条件都满足，$(1, -1)$ 是局部极小极大点。可是 $\phi'(1) = 2.618 \neq 0$，$\phi(1) = 3.023$，而外层真正的最优解是 $x = 0$。局部极小极大是相对于“内层只能看到附近”这个模型的结论，不能当作原问题的解来报告。

计算预算　不同方法每轮的工作量相差悬殊，一轮精确内解和一轮下降—上升不能直接比较。图 27.21是同一组运行的两种画法。(a) 按外层轮数，

27.1 极小极大问题
27.2 最坏值函数
27.3 鞍点
27.4 内层响应法
27.5 下降—上升方法
27.6 校正方向
27.7 结果评价
27.8 本章小结

$K=1$ 明显落后，$K=10$ 几乎与精确响应重合，$K=3$ 在这组系数下收缩最快；(b) 按梯度读取总数，$K=10$ 反而最慢，因为它每轮要读 11 次。

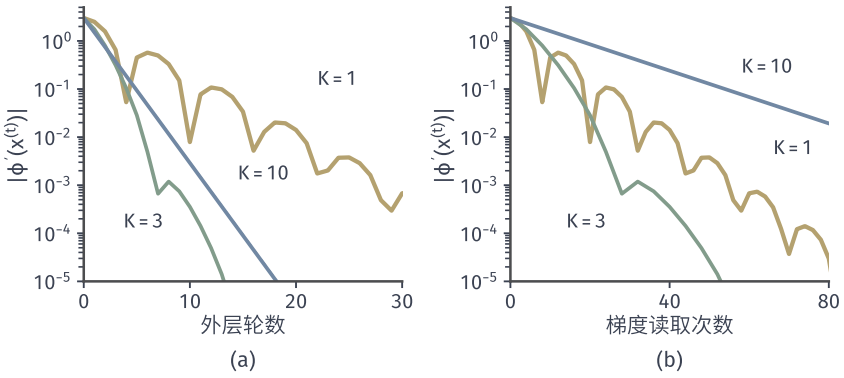


图 27.21 $f=-\frac{1}{2}x^2+2xy-\frac{1}{2}y^2$ 上每轮做 K 步内层上升的方法，$\alpha=\frac{1}{6}$，$\beta=\frac{1}{2}$，起点 $(1,0)$。黄线 $K=1$，绿线 $K=3$，蓝线 $K=10$。(a) 按外层轮数，灰色虚线是精确响应。(b) 同样的运行按梯度读取次数，每轮读取 $K+1$ 次。

报告的预算应当分开写明外层迭代次数、每次内层的计算量以及方向读取的总次数。这个例子里内层便宜且条件好，$K=3$ 在读取次数上最省。换一个问题，这个顺序可以完全不同。

27.8 本章小结

本章研究固定代价 f 下的问题 $\inf_{x}\sup_{y} f$，它有两层结构：外层最小化，内层取最坏情形。开头的三个困难，分别由最坏值函数、鞍点和更新动力学来回答，这三者回答的是不同的问题。

工具	回答的问题	依赖的条件
最坏值函数 ϕ	外层在最小化什么	$\boldsymbol{Y}$ 紧时连续，响应唯一时可微
全局鞍点与间隙	一对候选是否全局解	紧凸且凸凹时存在
迭代动力学	算法会不会靠近解	单调性、Lipschitz 性、步长

表 27.6 本章的三个主要工具。

顺序极小极大问题与同时下降—上升算法是两回事。前者是要解的数学问题，后者是一种迭代格式。图 27.5(c) 的原点是顺序问题的解，却不是鞍点；$f=xy$ 上的同时更新发散，问题本身却有鞍点。

判断一个结果可信，要分别核对四项条件：

1. 最值交换。只有凸凹性和相应的紧性成立时才能交换 inf 和 sup，值相等还要另外核对达到，才有鞍点。

2. 内层准确性。Danskin 公式要全局最优响应，局部极大不能代替。强凹时内层间隙能转成外层梯度的误差，非凹时梯度残差小不保证接近最坏值。

3. 耦合迭代的稳定。反对称的耦合产生旋转，下降—上升在双线性问题上不收敛。内层强凹时要让 $\boldsymbol{y}$ 跟得上，单调问题上可以用外梯度或乐观梯度校正方向。

4. 最终误差。间隙是全局证书，但只用近似内层算出的间隙偏小，需要修正；限定间隙和局部二阶条件都不能冒充全局结论。

本章两层共用同一个代价 f，内层想让 f 大，外层想让 f 小。下一章的两层目标各不相同，外层依赖内层的最优解，那时值函数的导数不再由这样简单的公式给出。

28.1 双层问题
28.1.1 唯一内解
28.1.2 多解选择
28.1.3 有限步内解
28.2 内层解映射
28.3 隐式微分
28.4 迭代展开
28.5 单层重述
28.6 外层求解
28.7 本章小结

第 28 章

双层优化

用一个数 $x \geq 0$ 控制一次拟合的保守程度：x 越大，拟合结果越被压向零。对每个 x，先解一个拟合问题，得到结果 y；再拿 y 和另一个固定的数比较，判断 x 选得好不好。要评价一个 x，必须先完成一次优化。这样的问题里，决策分成两层，上面一层的目标要读取下面一层的最优解。

这种嵌套带来三个问题。第一，下面一层可能无解，也可能有许多个同样好的解，“把内解代入外层”这句话要先说清选的是哪一个。第二，外层要下降就要知道目标对 x 的导数，而内解没有显式公式。第三，所有计算都只是近似，内层没解准、线性方程没解准、外层没走完，这几种误差要分开核算。

本章依次回答这三个问题。第 28.1节确定数学对象，区分唯一内解、多解选择和有限步输出。第 28.2节检查内解能否沿一条分支光滑变化，以及分支在什么地方断开。第 28.3节和第 28.4节给出两种求导路线，前者只看解点处的方程，后者沿算法的每一步传播导数。第 28.5节换一种思路，把内层最优性写成约束。第 28.6节把三类误差放在一起，给出外层的求解和停止依据。

28.1 双层问题

外层目标依赖内层的最优解时，它到底是一个什么样的函数？先把两层的角色写下来。

外层变量记为 $\boldsymbol{x} \in \boldsymbol{C} \subseteq \mathbb{R}^n$，内层变量记为 $\boldsymbol{y} \in \mathbb{R}^d$。外层选定 $\boldsymbol{x}$ 之后，内层在可行集 $\boldsymbol{Y}(\boldsymbol{x}) \subseteq \mathbb{R}^d$ 上最小化自己的目标 g；外层再用另一个目标 F 评价内层的结果。

定义 28.1　内层解集　给定 $\boldsymbol{x} \in \boldsymbol{C}$，称

$$\boldsymbol{S}(\boldsymbol{x}) = \arg\min_{\boldsymbol{y} \in \boldsymbol{Y}(\boldsymbol{x})} g(\boldsymbol{x}, \boldsymbol{y}) \tag{28.1}$$

> 为**内层解集**（lower-level solution set），其中的点称为内解。外层目标 $F(\boldsymbol{x}, \boldsymbol{y})$ 只对内解作评价，由此形成的嵌套问题称为**双层优化**（bilevel optimization）问题。

图 28.1是这个结构的全貌。$\boldsymbol{x}$ 有两条路影响外层：一条直接进入 F，另一条先改变内层问题，再通过选出的内解起作用。外层只能修改 $\boldsymbol{x}$，不能直接修改 $\boldsymbol{y}$。中间的“选解规则”一格是定义里没有出现、却必不可少的一步，第 28.1.2小节会讲它。

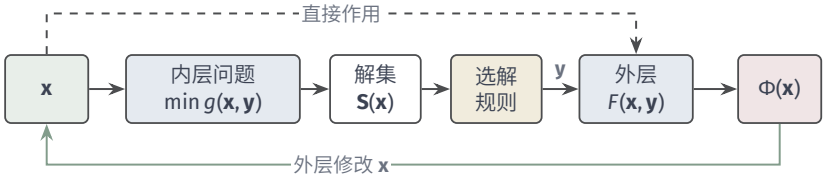


图 28.1　双层问题的结构。外层变量 $\boldsymbol{x}$ 决定内层问题，内层解集经选解规则给出 $\boldsymbol{y}$，外层目标 F 再读取 $\boldsymbol{y}$ 得到 $\Phi(\boldsymbol{x})$。虚线是 $\boldsymbol{x}$ 对 F 的直接作用，绿线表示外层根据 Φ 修改 $\boldsymbol{x}$。

内层无解时外层没有输入　解集可能是空集。取外层变量 $x \in \mathbb{R}$，内层变量 $y \in \mathbb{R}$，内层目标是

$$g(x, y) = \frac{x}{2} y^2 - y.$$

$x > 0$ 时这是开口向上的抛物线，唯一的内解是 $y = 1/x$。$x = 0$ 时 $g = -y$，$x < 0$ 时 g 是开口向下的抛物线，两种情况下 $y \to +\infty$ 都使 $g \to -\infty$，内层没有最小点。

这时一个内层算法仍然可以运行并输出数字。比如梯度下降的更新是 $y \leftarrow y + \alpha(1 - xy)$，在 $x < 0$ 时迭代会不断增大。把这种数字交给外层，得到的外层值不评价任何内解。因此外层只在下面的集合上比较：

$$\operatorname{dom} \boldsymbol{S} = \{\boldsymbol{x} \in \boldsymbol{C} : \boldsymbol{S}(\boldsymbol{x}) \neq \varnothing\}. \tag{28.2}$$

集合之外的 $\boldsymbol{x}$ 一律视为外层不可行，外层值规定为 $+\infty$。

与极小极大的区别　第 27章的问题 $\min_{\boldsymbol{x}} \max_{\boldsymbol{y}} f(\boldsymbol{x}, \boldsymbol{y})$ 也是嵌套的，形式上取 $g = -f$、$F = f$ 就是双层问题。可是那里两层围绕同一个代价相反地优化，内层的最优性恰好让外层目标对 $\boldsymbol{y}$ 的偏导为零。双层问题的两个目标一般无关，内层最优并不让 F 在 $\boldsymbol{y}$ 方向驻定，内解移动一点，外层值就跟着变化。表 28.1对比两者，第 28.3.1小节会用公式说明最后一行。

28.1 双层问题
28.1.1 唯一内解
28.1.2 多解选择
28.1.3 有限步内解
28.2 内层解映射
28.3 隐式微分
28.4 迭代展开
28.5 单层重述
28.6 外层求解
28.7 本章小结

	极小极大	双层优化
内外目标	同一个 f，方向相反	g 与 F 一般无关
内解处 $\nabla_{\boldsymbol{y}} F$	为零	一般不为零
外层导数	无需内解的响应项	必须计入内解的响应

表 28.1 极小极大与双层优化的对比。第二、三行假定内解唯一、位于内层可行集内部且相关函数可微。

28.1.1 唯一内解

最简单的情形是对每个 $\boldsymbol{x}$，解集恰有一个点，$\boldsymbol{S}(\boldsymbol{x}) = \{\boldsymbol{y}^\star(\boldsymbol{x})\}$。这时选解不成问题，外层目标是一个普通的函数。

定义 28.2 外层目标 设对每个 $\boldsymbol{x} \in \boldsymbol{C}$ 内解唯一，记为 $\boldsymbol{y}^\star(\boldsymbol{x})$。外层问题是在 $\boldsymbol{C}$ 上最小化

$$\Phi(\boldsymbol{x}) = F(\boldsymbol{x}, \boldsymbol{y}^\star(\boldsymbol{x})). \tag{28.3}$$

Φ 的变化有两个来源。$\boldsymbol{x}$ 变动时，F 的第一个位置直接变，这是直接作用；$\boldsymbol{y}^\star(\boldsymbol{x})$ 随之移动，F 的第二个位置也变，这是响应。后者才是双层问题的特点，第 28.3节专门计算它。

贯穿全章的正则拟合例 下面的例子贯穿全章。内层用观测值 3 拟合一个数 y，并用 $x \geq 0$ 惩罚 y 的大小；外层把结果和另一个固定的数 1 比较：

$$g(x, y) = \frac{1}{2}(y - 3)^2 + \frac{x}{2} y^2, \qquad F(x, y) = \frac{1}{2}(y - 1)^2. \tag{28.4}$$

对 y 求导并令导数为零，得到 $(1 + x)y - 3 = 0$。$x \geq 0$ 时 g 对 y 的二阶导数是 $1 + x > 0$，所以内解唯一：

$$y^\star(x) = \frac{3}{1 + x}. \tag{28.5}$$

代入式 (28.3)，外层目标是

$$\Phi(x) = \frac{1}{2}\Big(\frac{3}{1 + x} - 1\Big)^2.$$

当 $x = 2$ 时内解恰好等于 1，Φ 取到最小值 0。

两个目标为什么不能合并 看图 28.2(a)。粗线是 $y^\star(x)$ 的图像，只有粗线上的点才算内层最优。若把 x 和 y 一起放进 g 里最小化，得到的是空心点 $(0, 3)$，因为惩罚对 g 只是一种代价，g 总愿意取 $x = 0$。若把两者一起放

28.1 双层问题
28.1.1 唯一内解
28.1.2 多解选择
28.1.3 有限步内解
28.2 内层解映射
28.3 隐式微分
28.4 迭代展开
28.5 单层重述
28.6 外层求解
28.7 本章小结

进 F 里最小化，虚线 $y=1$ 上每一点都是最优的，x 完全不起作用，等于直接把拟合结果改成想要的数。

双层结构要求的是第三种做法：沿粗线走，在粗线上找 F 最小的点。这正像预算线上的最优：可选的点被限制在一条曲线上，只不过这条曲线本身要靠解优化问题才能画出来。图 28.2(b) 把粗线上的外层值画成 x 的函数，最小点在 $x=2$。

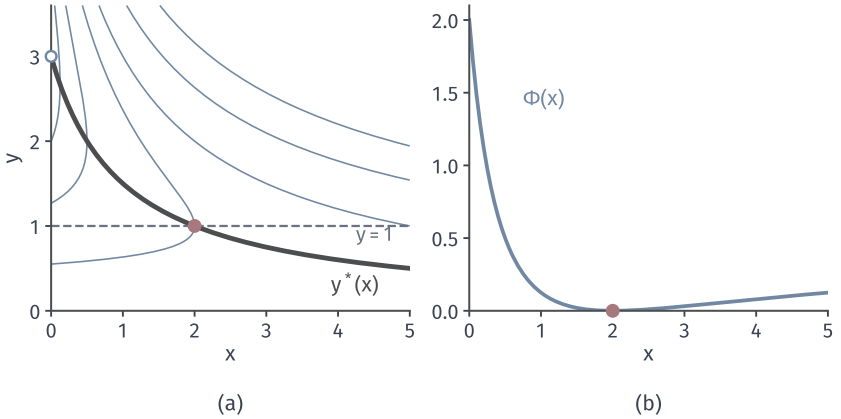


图 28.2 正则拟合例 (28.4)。(a) 蓝色细线是内层目标 g 的等高线，空心点 $(0,3)$ 是 g 对 (x,y) 的最小点；深灰粗线是内解曲线 $y^\star(x)=3/(1+x)$；虚线 $y=1$ 上 F 取最小值；红点 $(2,1)$ 是双层问题的解。(b) 外层目标 $\Phi(x)$，最小点是 $x=2$。

直接作用的例子 式 (28.4)中 F 不含 x，全部变化都来自响应。若外层再为 x 付出代价，比如把 F 换成 $\frac{1}{2}(y-1)^2+\frac{1}{10}x$，直接作用就出现了：$\Phi$ 多了一项 $\frac{1}{10}x$，最小点从 $x=2$ 向左移动。两个来源在导数中分别对应一项。

这里的 3 和 1 只是两个固定的数，本章把它们当作给定的优化数据。数据该怎样划分，这样选出的 x 有没有统计上的保证，不是优化问题，可参考卷八第 4 章“有限样本的误差上界”。

28.1.2 多解选择

解集可能含有许多点，它们对内层来说一样好，对外层却可能差别很大。这时 $F(\boldsymbol{x},\boldsymbol{y}^\star(\boldsymbol{x}))$ 这个写法失去了意义，必须补充一条规则。

两种选解规则 可以用一个比喻来理解。外层是提要求的一方，内层是执行的一方，执行方在几个同样好的方案之间不在乎选哪个。外层可以假定执行方会配合自己，也可以防备它选最不利的。这个比喻只用来记住两种规则，数学上并不要求内层真有什么意愿，规则只是对解集中的点作出约定。

定义 28.3 乐观模型与悲观模型 对 $\boldsymbol{x} \in \operatorname{dom} \boldsymbol{S}$，定义

$$\Phi_{\mathrm{o}}(\boldsymbol{x}) = \inf_{\boldsymbol{y} \in \boldsymbol{S}(\boldsymbol{x})} F(\boldsymbol{x}, \boldsymbol{y}), \tag{28.6}$$

$$\Phi_{\mathrm{p}}(\boldsymbol{x}) = \sup_{\boldsymbol{y} \in \boldsymbol{S}(\boldsymbol{x})} F(\boldsymbol{x}, \boldsymbol{y}), \tag{28.7}$$

对 $\boldsymbol{x} \notin \operatorname{dom} \boldsymbol{S}$，两者都规定为 $+\infty$。在 $\boldsymbol{C}$ 上最小化 Φ_{o} 称为**乐观模型**（optimistic model），最小化 Φ_{p} 称为**悲观模型**（pessimistic model）。

空集上的规定要单独写出。按惯例 $\sup \varnothing = -\infty$，若照搬，内层无解的 $\boldsymbol{x}$ 在悲观模型中外层值是 $-\infty$，反而成了最好的选择，这与第 28.1节开头的约定相反。

两个函数处处满足 $\Phi_{\mathrm{o}} \le \Phi_{\mathrm{p}}$，内解唯一时都等于 Φ。乐观模型的 inf 可以和外层的 inf 合并，于是

$$\inf_{\boldsymbol{x} \in \boldsymbol{C}} \Phi_{\mathrm{o}}(\boldsymbol{x}) = \inf\{F(\boldsymbol{x}, \boldsymbol{y}) : \boldsymbol{x} \in \boldsymbol{C},\ \boldsymbol{y} \in \boldsymbol{S}(\boldsymbol{x})\}. \tag{28.8}$$

乐观模型因而是一个对 $(\boldsymbol{x}, \boldsymbol{y})$ 的联合最小化，可行集是解集的图像。悲观模型夹着一层 sup，不能这样合并。

一个手算例子 取 $\boldsymbol{C}$ 和内层可行集都是 $[-1, 1]$，目标是

$$g(x, y) = xy, \qquad F(x, y) = x^2 + y.$$

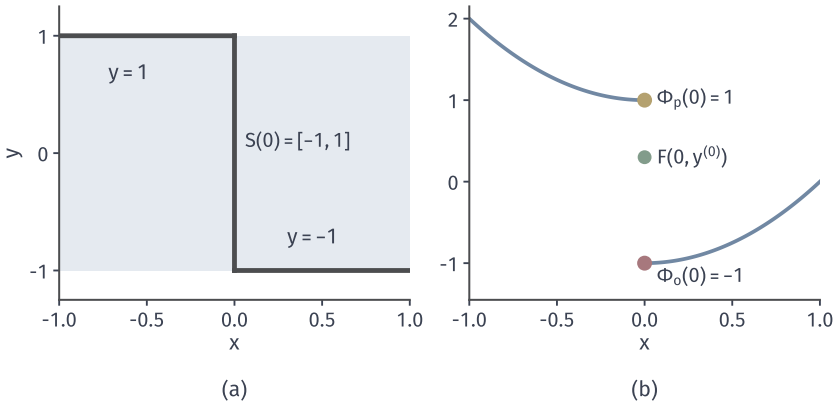
内层在 $[-1, 1]$ 上最小化关于 y 的线性函数，解由 x 的符号决定：

$$S(x) = \begin{cases} \{1\}, & x < 0, \\ [-1, 1], & x = 0, \\ \{-1\}, & x > 0. \end{cases}$$

$x \neq 0$ 时只有一个内解，两种模型相同：$x < 0$ 时外层值是 $x^2 + 1$，$x > 0$ 时外层值是 $x^2 - 1$。分歧只在 $x = 0$，此时整个区间都是内解，$F(0, y) = y$，于是

$$\Phi_{\mathrm{o}}(0) = -1, \qquad \Phi_{\mathrm{p}}(0) = 1.$$

图 28.3画出了这个例子。乐观模型在 $x = 0$ 取到最小值 -1，红点就是它的解。悲观模型的下确界同样是 -1，因为 $x \downarrow 0$ 时 $x^2 - 1 \to -1$，但这个值取不到：$x = 0$ 处值跳到 1，$x > 0$ 时值严格大于 -1。悲观模型没有最优解。



(a) (b)

图 28.3 多解时的选解。内层 $g = xy$，$x, y \in [-1, 1]$，外层 $F = x^2 + y$。(a) 浅蓝是内层可行集，深灰线是解集 $S(x)$ 的图像，$x = 0$ 处是整段区间。(b) 蓝线是 $x \neq 0$ 时共同的外层值。$x = 0$ 处，红点是乐观值，黄点是悲观值，绿点是从 $y^{(0)} = 0.3$ 出发的投影梯度法实际得到的外层值。

乐观模型的解存在，悲观模型没有这样的保证 上例不是偶然的。把式 (28.8)看成解集图像上的最小化，就可以套用第 1章的存在定理，只需说明图像是紧的。

定理 28.4 乐观模型解的存在 设 $\boldsymbol{C}$ 和 $\boldsymbol{Y}$ 是非空紧集，内层可行集恒为 $\boldsymbol{Y}$，g 和 F 在 $\boldsymbol{C} \times \boldsymbol{Y}$ 上连续。则集合

$$\boldsymbol{G} = \{(\boldsymbol{x}, \boldsymbol{y}) : \boldsymbol{x} \in \boldsymbol{C},\ \boldsymbol{y} \in \boldsymbol{S}(\boldsymbol{x})\} \tag{28.9}$$

非空且紧，乐观模型有最优解。

证明 对每个 $\boldsymbol{x} \in \boldsymbol{C}$，连续函数 $g(\boldsymbol{x}, \cdot)$ 在紧集 $\boldsymbol{Y}$ 上取得最小值，所以 $\boldsymbol{S}(\boldsymbol{x})$ 非空，$\boldsymbol{G}$ 非空。$\boldsymbol{G}$ 含于紧集 $\boldsymbol{C} \times \boldsymbol{Y}$，只需证明它是闭集。

取 $\boldsymbol{G}$ 中收敛到 $(\boldsymbol{x}, \boldsymbol{y})$ 的序列 $(\boldsymbol{x}^{(k)}, \boldsymbol{y}^{(k)})$。$\boldsymbol{C}$、$\boldsymbol{Y}$ 闭，所以 $\boldsymbol{x} \in \boldsymbol{C}$，$\boldsymbol{y} \in \boldsymbol{Y}$。任取比较点 $\boldsymbol{z} \in \boldsymbol{Y}$，由 $\boldsymbol{y}^{(k)}$ 是内解，有

$$g(\boldsymbol{x}^{(k)}, \boldsymbol{y}^{(k)}) \leq g(\boldsymbol{x}^{(k)}, \boldsymbol{z}).$$

令 $k \to \infty$，由 g 连续，得到

$$g(\boldsymbol{x}, \boldsymbol{y}) \leq g(\boldsymbol{x}, \boldsymbol{z}).$$

$\boldsymbol{z}$ 是任取的，所以 $\boldsymbol{y} \in \boldsymbol{S}(\boldsymbol{x})$，$\boldsymbol{G}$ 是闭集。连续函数 F 在紧集 $\boldsymbol{G}$ 上取得最小值，由式 (28.8)，它就是乐观模型的最优值。 ■

28.1 双层问题
28.1.1 唯一内解
28.1.2 多解选择
28.1.3 有限步内解
28.2 内层解映射
28.3 隐式微分
28.4 迭代展开
28.5 单层重述
28.6 外层求解
28.7 本章小结

前面的例子满足定理的全部条件，悲观模型却没有解。原因是第 1章存在论证的第三关：悲观目标在 $x=0$ 处向上跳，不是下半连续的。

算法的隐含择解 实际运行时，算法既不会自动做 inf，也不会自动做 sup。上例中 $x=0$ 时内层梯度是 $\partial_y g = x = 0$，投影梯度法根本不动，停在初值。从 $y^{(0)}=0.3$ 出发，得到外层值 $F(0,0.3)=0.3$，这就是图 28.3(b) 的绿点，它既不是乐观值，也不是悲观值。

所以声称求解某个模型时，要说清算法的输出怎样对应这个模型；对应不上的话，算出来的只是“这个算法从这个初值给出的外层值”。

28.1.3 有限步内解

精确内解通常拿不到，实际手里的是算法运行若干步的结果。这个结果也是 $\boldsymbol{x}$ 的函数，但它和内解是不同的对象。

定义 28.5 有限步目标 给定内层算法的初始化和更新规则，把运行 T 步的输出记为 $\boldsymbol{y}^{(T)}(\boldsymbol{x})$。称

$$\Phi_T(\boldsymbol{x}) = F\big(\boldsymbol{x}, \boldsymbol{y}^{(T)}(\boldsymbol{x})\big) \tag{28.10}$$

为**有限步目标**（finite-step objective）。

这个函数依赖初值、更新规则、步长和步数，换掉任何一项就是另一个函数。

用正则拟合例计算 对式 (28.4)的内层用梯度下降，初值 $y^{(0)}=0$，步长 $\alpha = 1/2$。内层梯度是 $(1+x)y-3$，代入更新式，得到

$$y^{(t+1)} = y^{(t)} - \frac{1}{2}\big[(1+x)y^{(t)} - 3\big] = q\,y^{(t)} + \frac{3}{2}, \qquad q = \frac{1-x}{2}.$$

减去不动点 $y^\star(x)$，误差每步乘 q，初始误差是 $-y^\star(x)$，所以

$$y^{(T)}(x) = y^\star(x)\big(1 - q^T\big). \tag{28.11}$$

T 较小时可以写成多项式。前两步的结果是

$$y^{(1)} = \frac{3}{2}, \qquad y^{(2)} = \frac{9}{4} - \frac{3}{4}x.$$

$y^{(1)}$ 与 x 无关，于是 Φ_1 是常数，走一步完全看不到 x 的作用。Φ_2 的最小点由 $y^{(2)}=1$ 确定，得到 $x=5/3$，与 Φ 的最小点 $x=2$ 不同。

28.1 双层问题
28.2 内层解映射
28.2.1 可微分支
28.2.2 分支切换
28.3 隐式微分
28.4 迭代展开
28.5 单层重述
28.6 外层求解
28.7 本章小结

再看 $T=3$。直接计算得 $y^{(3)}=\frac{3}{2}(q^2+q+1)$，它在 $q=-1/2$ 时最小，最小值是 $9/8$。这时 $y^{(3)}$ 到不了 1，Φ_3 的最小点是 $x=2$，最小值却是 $1/128$，不是 0。图 28.4比较了几个 T。

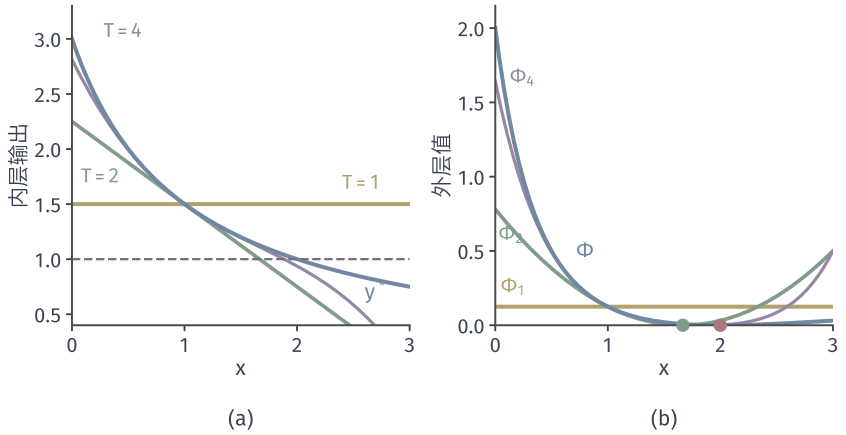


图 28.4 有限步内解与有限步目标，内层梯度下降取 $y^{(0)}=0$、$\alpha=1/2$。(a) 内层输出 $y^{(T)}(x)$（$T=1,2,4$）与精确内解 $y^\star(x)$（蓝）；所有曲线在 $x=1$ 相交，因为此时 $q=0$，一步即得精确解。(b) 对应的 Φ_T 与 Φ。绿点是 Φ_2 的最小点 $x=5/3$，红点是 Φ 的最小点 $x=2$。

设计目标还是近似手段 这里要区分两种立场。第一种，最终交付的就是“运行 T 步的这个过程”，T 和初值是设计的一部分，那么 Φ_T 本身就是要优化的目标，它的梯度是精确的，不必谈 $\boldsymbol{y}^\star$。第二种，真正关心的是最优选解，T 步只是不得已的近似，那么 Φ_T 与 Φ 的差别就是要核算的误差。

两种立场下同一个数字含义不同，不能因为运行的是优化算法，就把 $\boldsymbol{y}^{(T)}(\boldsymbol{x})$ 称作 $\boldsymbol{y}^\star(\boldsymbol{x})$。表 28.2列出本节得到的三个对象。

对象	需要说明什么	依赖
内解唯一的 Φ	唯一性	问题本身
Φ_{o}、Φ_{p}	乐观或悲观	问题与规则
Φ_T	初值、更新、步数	算法实现

表 28.2 外层目标的三种对象。内层无解的 $\boldsymbol{x}$ 不属于前两行的讨论范围。

28.2 内层解映射

外层要下降，需要知道 Φ 的导数，而 Φ 里含着内解。内解能不能看成 $\boldsymbol{x}$ 的光滑函数？这个问题要分范围回答，因为“内解”可以指三种不同范围的东西：全局解集、某个局部极小点所在的分支，以及只满足驻点方程的点。

第 19章已经研究过解随参数的变化。本节把那里的结论放到双层语境中使用：先确定追踪的是哪个范围的分支，再讨论能否对它求导。

28.1 双层问题
28.2 内层解映射
28.2.1 可微分支
28.2.2 分支切换
28.3 隐式微分
28.4 迭代展开
28.5 单层重述
28.6 外层求解
28.7 本章小结

28.2.1 可微分支

先看无约束内层，$\boldsymbol{Y}(\boldsymbol{x}) = \mathbb{R}^d$。内层的碗底满足驻点方程 $\nabla_{\boldsymbol{y}} g = \boldsymbol{0}$。外层变量一动，碗的形状变化，碗底跟着移动，移动多少由碗的曲率决定：曲率大的方向，碗底只需挪一点就能抵消梯度的变化。

局部分支 记 $(\boldsymbol{x}_0, \boldsymbol{y}_0)$ 为基准点。下面的定理就是第 19章的无约束解导数定理，这里按双层记号复述。

定理 28.6 局部极小分支 设 g 在 $(\boldsymbol{x}_0, \boldsymbol{y}_0)$ 的邻域内二阶连续可微，$\nabla_{\boldsymbol{y}} g(\boldsymbol{x}_0, \boldsymbol{y}_0) = \boldsymbol{0}$，且 $\nabla^2_{\boldsymbol{yy}} g(\boldsymbol{x}_0, \boldsymbol{y}_0) \succ \boldsymbol{0}$。则存在 $\boldsymbol{x}_0$ 的邻域 $\boldsymbol{U}$、$\boldsymbol{y}_0$ 的邻域 $\boldsymbol{V}$ 和唯一的连续可微映射 $\hat{\boldsymbol{y}} : \boldsymbol{U} \to \boldsymbol{V}$，使 $\hat{\boldsymbol{y}}(\boldsymbol{x}_0) = \boldsymbol{y}_0$，并且对 $\boldsymbol{x} \in \boldsymbol{U}$ 有

$$\nabla_{\boldsymbol{y}} g(\boldsymbol{x}, \hat{\boldsymbol{y}}(\boldsymbol{x})) = \boldsymbol{0}, \tag{28.12}$$

每个 $\hat{\boldsymbol{y}}(\boldsymbol{x})$ 都是 $g(\boldsymbol{x}, \cdot)$ 的严格局部极小点。其 Jacobian 矩阵为

$$\boldsymbol{D}(\boldsymbol{x}) = \frac{\partial \hat{\boldsymbol{y}}}{\partial \boldsymbol{x}} = -\boldsymbol{H}^{-1}\boldsymbol{B}, \tag{28.13}$$

其中 $\boldsymbol{H} = \nabla^2_{\boldsymbol{yy}} g$ 是 $d \times d$ 矩阵，$\boldsymbol{B} = \nabla^2_{\boldsymbol{yx}} g$ 是 $d \times n$ 矩阵，其 (i, j) 元素是 $\partial^2 g / \partial y_i \partial x_j$，两者都在 $(\boldsymbol{x}, \hat{\boldsymbol{y}}(\boldsymbol{x}))$ 处取值。

证明 把驻点方程 $\nabla_{\boldsymbol{y}} g(\boldsymbol{x}, \boldsymbol{y}) = \boldsymbol{0}$ 看成 d 个方程、d 个未知量 $\boldsymbol{y}$、参数 $\boldsymbol{x}$ 的系统。它对 $\boldsymbol{y}$ 的 Jacobian 矩阵是 $\boldsymbol{H}$，在基准点正定，因而可逆。隐函数定理给出邻域和唯一的连续可微分支，定理的陈述可参考卷二第 22 章“隐函数与反函数”。

沿分支式 (28.12)恒成立，对 $\boldsymbol{x}$ 求导，得到

$$\boldsymbol{H}\boldsymbol{D} + \boldsymbol{B} = \boldsymbol{0},$$

这就是式 (28.13)。

Hessian 连续，矩阵最小特征值连续依赖矩阵，所以缩小 $\boldsymbol{U}$ 后沿分支 $\boldsymbol{H} \succ \boldsymbol{0}$。驻点处 Hessian 正定，由二阶充分条件，$\hat{\boldsymbol{y}}(\boldsymbol{x})$ 是严格局部极小点。 ■

定理的三个条件各有作用。二阶连续可微使驻点方程本身连续可微。驻点方程保证基准点在分支上。Hessian 正定有两份工作：它的可逆性给出分支，它的正定性保证分支上的点是极小点而不是别的驻点。

结论是局部的。定理说的是基准点附近有一条光滑的局部极小点曲线，没有说这些点是内层的全局最优解，所以这时的 $\hat{\boldsymbol{y}}(\boldsymbol{x})$ 还不能当作 $\boldsymbol{S}(\boldsymbol{x})$ 中的点。

全局强凸时分支就是唯一内解 要让分支代表全局内解，需要全局的条件。强凸是最常用的一个。

定理 28.7 强凸内层的解映射 设 $\boldsymbol{U} \subseteq \mathbb{R}^n$ 开，$\boldsymbol{Y}(\boldsymbol{x}) = \mathbb{R}^d$，$g$ 在 $\boldsymbol{U} \times \mathbb{R}^d$ 上二阶连续可微，且存在 $\mu > 0$，使 $\nabla^2_{\boldsymbol{yy}} g \succeq \mu \boldsymbol{I}$ 处处成立。则对每个 $\boldsymbol{x} \in \boldsymbol{U}$，内解存在且唯一，$\boldsymbol{y}^\star$ 在 $\boldsymbol{U}$ 上连续可微，其 Jacobian 矩阵 $\boldsymbol{D}$ 由式 (28.13)给出，并满足

$$\|\boldsymbol{D}(\boldsymbol{x})\|_2 \le \frac{\|\boldsymbol{B}\|_2}{\mu}. \tag{28.14}$$

证明 固定 $\boldsymbol{x} \in \boldsymbol{U}$，把 $g(\boldsymbol{x}, \cdot)$ 简写成 ϕ。由带积分余项的 Taylor 公式和 Hessian 下界，对任意 $\boldsymbol{y}, \boldsymbol{z}$ 有

$$\phi(\boldsymbol{z}) \ge \phi(\boldsymbol{y}) + \langle \nabla\phi(\boldsymbol{y}), \boldsymbol{z} - \boldsymbol{y} \rangle + \frac{\mu}{2}\|\boldsymbol{z} - \boldsymbol{y}\|_2^2.$$

取 $\boldsymbol{y} = \boldsymbol{0}$，右端随 $\|\boldsymbol{z}\|_2 \to \infty$ 趋于 $+\infty$，所以下水平集有界。ϕ 连续，下水平集也是闭集，因而紧。由第 1章的紧下水平集存在定理，最小点存在。

若 $\boldsymbol{y}$ 是驻点，上面的不等式给出 $\phi(\boldsymbol{z}) > \phi(\boldsymbol{y})$ 对一切 $\boldsymbol{z} \neq \boldsymbol{y}$ 成立。所以驻点就是唯一的全局最小点，内解唯一。

任取 $\boldsymbol{x}_0 \in \boldsymbol{U}$，定理 28.6在 $(\boldsymbol{x}_0, \boldsymbol{y}^\star(\boldsymbol{x}_0))$ 处给出局部分支 $\hat{\boldsymbol{y}}$。分支上的点都是驻点，而驻点就是内解，所以在 $\boldsymbol{x}_0$ 附近 $\hat{\boldsymbol{y}} = \boldsymbol{y}^\star$。因此 $\boldsymbol{y}^\star$ 连续可微，导数公式成立。由 $\boldsymbol{H} \succeq \mu \boldsymbol{I}$ 得 $\|\boldsymbol{H}^{-1}\|_2 \le 1/\mu$，这就给出式 (28.14)。 ∎

对正则拟合例，g 对 y 的二阶导数是 $1 + x$，在开集 $x > -1/2$ 上不小于 $\mu = 1/2$，定理适用，在 $x \ge 0$ 上还可以取 $\mu = 1$。这里 $B = \partial^2 g / \partial y \partial x = y$，代入式 (28.13)，得到

$$\frac{\mathrm{d}y^\star}{\mathrm{d}x} = -\frac{y^\star}{1 + x} = -\frac{3}{(1 + x)^2}.$$

这与直接对式 (28.5)求导的结果相同。

去掉条件会怎样 只要求驻点方程的 Jacobian 矩阵可逆是不够的。取 $g(x, y) = -\frac{1}{2}(y - x)^2$，驻点方程是 $x - y = 0$，对 y 的导数是 -1，可

28.1 双层问题
28.2 内层解映射
28.2.1 可微分支
28.2.2 分支切换
28.3 隐式微分
28.4 迭代展开
28.5 单层重述
28.6 外层求解
28.7 本章小结

逆，驻点分支 $y = x$ 十分光滑。可是这条分支上每一点都是极大点，内层根本没有最小点，$\boldsymbol{S}(x)$ 是空集。隐函数定理只管方程，不管方程的解是不是极小点。

反过来，内解唯一也不保证可微。取

$$g(x, y) = \frac{1}{4}y^4 - xy.$$

对每个 x，g 严格凸且有下界，唯一内解由 $y^3 = x$ 给出，即 $y^\star(x) = x^{1/3}$。它在 $\mathbb{R}$ 上连续，但在 $x = 0$ 处切线竖直，导数不存在。原因是 $H = 3y^2$ 在 $y = 0$ 处为零，碗底在 $x = 0$ 时变得完全平坦，如图 28.5所示。这也说明严格凸不能代替强凸。

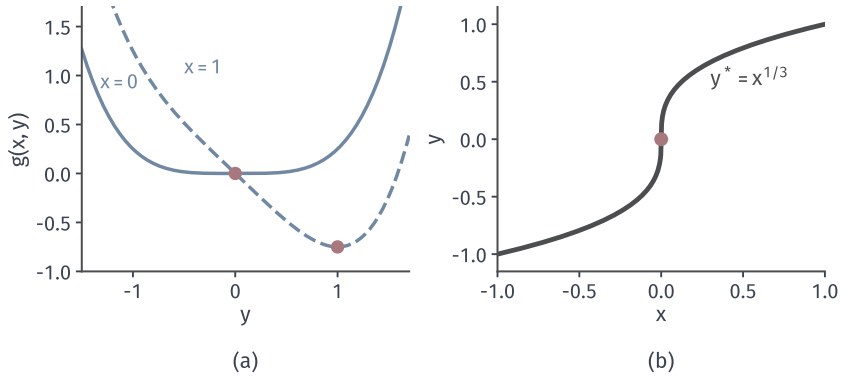


图 28.5 内解唯一但不可微，$g = y^4/4 - xy$。(a)$x = 0$（实线）的碗底平坦，$H = 0$；$x = 1$（虚线）的碗底在 $y = 1$，红点是内解。(b) 内解曲线 $y^\star = x^{1/3}$ 连续，红点 $x = 0$ 处切线竖直。

28.2.2 分支切换

内层非凸时，几个局部极小点可能并存，谁是全局最优随 $\boldsymbol{x}$ 改变。局部分支一直光滑，全局选解却可能在某处跳到另一条分支上。

两个碗交换优劣 构造一个可以手算的内层，它由两个抛物线取下包络：

$$g(x, y) = \min\left\{\frac{1}{2}(y - 1 - x)^2 - x,\ \frac{1}{2}(y + 1 - x)^2 + x\right\}. \tag{28.15}$$

令两式相等并化简，可知两条抛物线始终在 $y = 0$ 处相交，那里是两个碗之间的山脊。山脊不在碗底，所以每个碗底附近 g 就是一条光滑的抛物线，定理 28.6适用。第一个碗的碗底 $y_+(x) = x + 1$ 在 $x > -1$ 时位于山脊右侧，第二个碗的碗底 $y_-(x) = x - 1$ 在 $x < 1$ 时位于山脊左侧。两个碗底的高度分别是

$$g(x, y_+(x)) = -x, \qquad g(x, y_-(x)) = x.$$

所以 $x>0$ 时右边的碗更低，$x<0$ 时左边的碗更低，$x=0$ 时打平。全局解集是

$$S(x)=\begin{cases}\{x-1\}, & x<0,\\ \{-1,\,1\}, & x=0,\\ \{x+1\}, & x>0.\end{cases}$$

图 28.6(a) 画了三个 x 处的 g，(b) 画了解曲线。全局选解在 $x=0$ 处从下面一条分支跳到上面一条，两条分支本身都连续穿过 $x=0$。

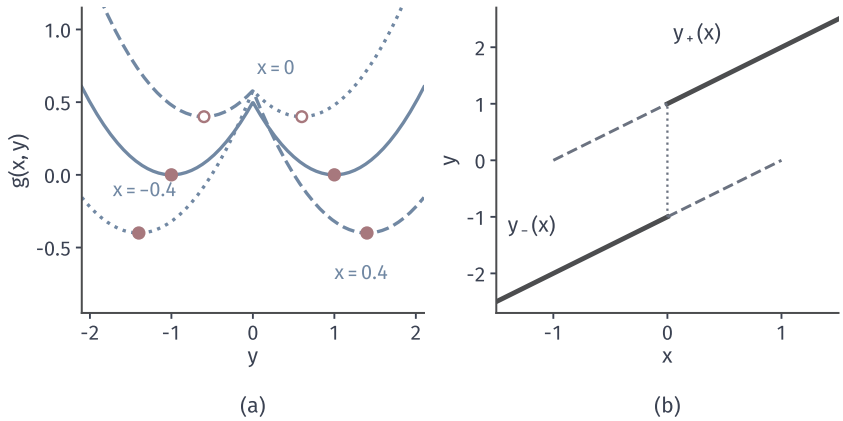


图 28.6　两个内层极小点交换优劣，g 由式 (28.15)定义。(a)$x=-0.4,0,0.4$ 时的 g，红色实心点是全局极小点，空心点是非全局的局部极小点。(b) 深灰粗线是全局内解，灰色虚线是仍为局部极小点、但已不是全局最优的分支延续，点线标出 $x=0$ 处的跳变。

外层目标跟着跳　取外层目标 $F=\frac{1}{2}(y-\frac{1}{2})^2$。沿两条分支的外层值分别是

$$\Phi_+(x)=\frac{1}{2}\Big(x+\frac{1}{2}\Big)^2,\qquad \Phi_-(x)=\frac{1}{2}\Big(x-\frac{3}{2}\Big)^2.$$

全局选解的外层值在 $x>0$ 时是 Φ_+，在 $x<0$ 时是 Φ_-。在 $x=0$ 处从左极限 $9/8$ 跳到右极限 $1/8$，Φ 在这里甚至不连续。乐观模型在 $x=0$ 选 $y=1$，值为 $1/8$；悲观模型选 $y=-1$，值为 $9/8$。

算法实际追踪的是哪一条　现在假定外层用梯度下降，内层每次从上一轮的解继续求解。这种**热启动**（warm start）使内层一直留在右边的碗里。若沿分支用光滑公式，外层迭代是

$$x^{(t+1)}=x^{(t)}-\eta\,\Phi_+'(x^{(t)})=x^{(t)}-\eta\Big(x^{(t)}+\frac{1}{2}\Big).$$

从 $x^{(0)}=0.8$ 出发，取 $\eta=0.3$，迭代穿过 $x=0$，一路收敛到 $x=-\frac{1}{2}$，此时外层值看上去是 0。这是图 28.7中的绿色路径。

28.1 双层问题
28.2 内层解映射
28.3 隐式微分
28.3.1 超梯度
28.3.2 线性方程求解
28.3.3 约束内层
28.4 迭代展开
28.5 单层重述
28.6 外层求解
28.7 本章小结

可是 $x=-\frac{1}{2}$ 时右边的碗已经不是全局最优了。真正的内解在左边的碗里，$y_-(-\frac{1}{2})=-\frac{3}{2}$，真实的外层值是

$$\Phi_-\left(-\frac{1}{2}\right)=\frac{1}{2}\left(-\frac{1}{2}-\frac{3}{2}\right)^2=2.$$

算法报告的 0 和真实的 2 之间差了一条红色点线的距离，而算法运行中没有任何量发出警告，因为沿局部分支一切都光滑。

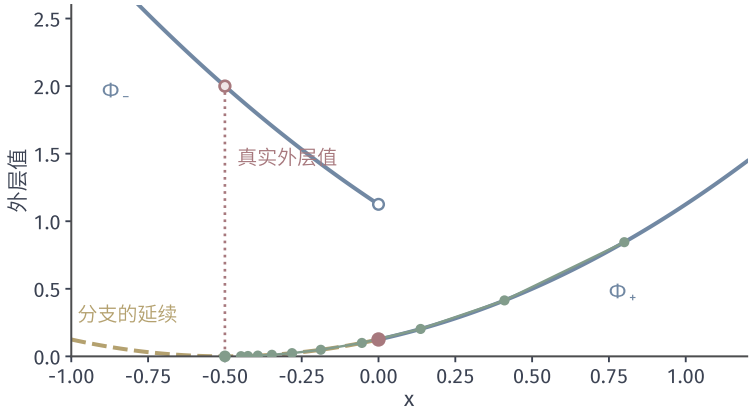


图 28.7 全局选解的外层值在切换点跳变，$F=\frac{1}{2}(y-\frac{1}{2})^2$。蓝线是全局选解的外层值，$x=0$ 处的空心点是左极限 9/8，红点是右极限 1/8，也是乐观模型在 $x=0$ 的值。黄色虚线是分支 Φ_+ 越过切换点后的延续，绿色路径是沿这条分支的外层梯度下降，它停在 $x=-1/2$。红色空心点是此处真实的外层值 2。

表 28.3分清这里出现的三个“导数”。切换点处不能继续套用同一个光滑公式，这个公式求的是局部分支的导数，在切换点那一边它不再描述全局选解。

对象	例中 $x=-0.1$ 处	成立范围
局部分支导数 Φ'_+	0.4	分支存续的区间
全局选解导数 Φ'_-	-1.6	不含切换点的区间
算法返回的导数	取决于碗的选择	取决于初值、热启动

表 28.3 分支切换时要区分的三种导数。例中 $x=-0.1$ 时全局内解在左边的碗，热启动的算法却可能仍在右边的碗。

28.3 隐式微分

在定理 28.6成立的分支上，怎样计算外层目标的导数？关键的观察是，求导只需要当前解点处的局部关系。至于这个解是怎样迭代得到的，算法走过了多少步，都不进入公式，也不必保存。

28.1 双层问题
28.2 内层解映射
28.3 隐式微分
28.3.1 超梯度
28.3.2 线性方程求解
28.3.3 约束内层
28.4 迭代展开
28.5 单层重述
28.6 外层求解
28.7 本章小结

28.3.1 超梯度

设 $\hat{\boldsymbol{y}}(\boldsymbol{x})$ 是所追踪的分支，外层目标为 $\Phi(\boldsymbol{x}) = F(\boldsymbol{x}, \hat{\boldsymbol{y}}(\boldsymbol{x}))$。若内解唯一且满足定理 28.7，这条分支就是 $\boldsymbol{y}^\star(\boldsymbol{x})$。$\Phi$ 对 $\boldsymbol{x}$ 的梯度称为**超梯度**（hypergradient）。“超”在这里指外层，与第 22章凹函数的超梯度（supergradient）是两回事。

主要思想：把响应接到外层 由链式法则，Φ 的梯度由两部分组成：

$$\nabla \Phi = \nabla_{\boldsymbol{x}} F + \boldsymbol{D}^{\top} \nabla_{\boldsymbol{y}} F.$$

第一项是直接作用，第二项是响应。把式 (28.13)代入第二项，并利用 $\boldsymbol{H}$ 对称，得到

$$\boldsymbol{D}^{\top} \nabla_{\boldsymbol{y}} F = -\boldsymbol{B}^{\top} \boldsymbol{H}^{-1} \nabla_{\boldsymbol{y}} F.$$

这个式子不必先算出 $\boldsymbol{H}^{-1}\boldsymbol{B}$ 这个 $d \times n$ 矩阵。先解一个以 $\nabla_{\boldsymbol{y}} F$ 为右端的方程，得到的向量再乘 $\boldsymbol{B}^{\top}$ 即可。

定理 28.8 隐式超梯度 设定理 28.6的条件成立，F 在 $(\boldsymbol{x}_0, \boldsymbol{y}_0)$ 附近连续可微。则 $\Phi(\boldsymbol{x}) = F(\boldsymbol{x}, \hat{\boldsymbol{y}}(\boldsymbol{x}))$ 连续可微，且

$$\nabla \Phi = \nabla_{\boldsymbol{x}} F - \boldsymbol{B}^{\top} \boldsymbol{v}, \qquad \boldsymbol{H} \boldsymbol{v} = \nabla_{\boldsymbol{y}} F, \tag{28.16}$$

其中所有导数都在 $(\boldsymbol{x}, \hat{\boldsymbol{y}}(\boldsymbol{x}))$ 处取值。

证明 $\hat{\boldsymbol{y}}$ 连续可微，F 连续可微，由链式法则 Φ 连续可微，其梯度是上面的两项之和。$\boldsymbol{H}$ 正定，所以方程 $\boldsymbol{H}\boldsymbol{v} = \nabla_{\boldsymbol{y}} F$ 有唯一解，即 $\boldsymbol{v} = \boldsymbol{H}^{-1} \nabla_{\boldsymbol{y}} F$，代入即得式 (28.16)。 ■

式 (28.16)中的 $\boldsymbol{H}\boldsymbol{v} = \nabla_{\boldsymbol{y}} F$ 称为**伴随方程**（adjoint equation）。用这种方法求超梯度的做法称为**隐式微分**（implicit differentiation），因为内解没有显式公式，导数是从定义它的方程中得出的。

$\boldsymbol{v}$ 是内层梯度的价格 $\boldsymbol{v}$ 有一个直接的含义。设想把驻点方程改成 $\nabla_{\boldsymbol{y}} g = \boldsymbol{\varepsilon}$，也就是给内层梯度一点小扰动。内解移动 $\boldsymbol{H}^{-1}\boldsymbol{\varepsilon}$，外层值变化约为

$$\langle \nabla_{\boldsymbol{y}} F, \boldsymbol{H}^{-1} \boldsymbol{\varepsilon} \rangle = \langle \boldsymbol{v}, \boldsymbol{\varepsilon} \rangle.$$

所以 $\boldsymbol{v}$ 是内层梯度每单位扰动在外层的价格，含义和约束乘子作为影子价格相同。

$\boldsymbol{x}$ 改变 $\Delta\boldsymbol{x}$ 时，内层梯度在原来的解点偏移 $\boldsymbol{B}\Delta\boldsymbol{x}$，内解要把这份偏移抵消掉，相当于对内层施加了 $-\boldsymbol{B}\Delta\boldsymbol{x}$ 的扰动。价格乘以扰动量，就得到响应项 $-\langle \boldsymbol{B}^{\top}\boldsymbol{v}, \Delta\boldsymbol{x}\rangle$。这个价格只在一阶范围内有效，$\Delta\boldsymbol{x}$ 大了或分支切换了，它就不再准确。

图 28.8把这条因果链画了出来。上面一行顺着原因往下算，要带着 n 个方向的 $\Delta\boldsymbol{x}$ 走完全程。下面一行从外层往回算，只带一个向量。标量外层目标、很多外层变量时，后者便宜得多。

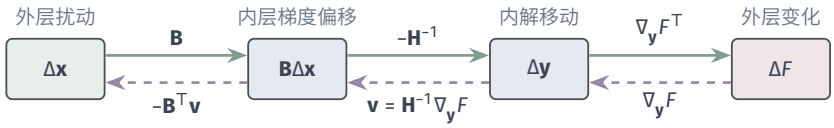


图 28.8　超梯度的因果链。绿色实线从外层扰动算到外层变化，每个方向 $\Delta\boldsymbol{x}$ 算一次。紫色虚线从外层梯度往回算，一次得到全部分量的梯度，$\boldsymbol{v}$ 是内层梯度偏移的价格。

手算核对　对正则拟合例 (28.4)，在 $x=1$ 处，各量为

$$y^{\star}=\frac{3}{2},\qquad H=1+x=2,\qquad B=y^{\star}=\frac{3}{2},\qquad \partial_y F=y^{\star}-1=\frac{1}{2}.$$

解伴随方程，得到

$$v=\frac{\partial_y F}{H}=\frac{1}{4}.$$

F 不含 x，所以由式 (28.16)，

$$\Phi'(1)=0-Bv=-\frac{3}{8}.$$

直接对 Φ 求导来核对。由链式法则，

$$\Phi'(x)=(y^{\star}-1)\,\frac{\mathrm{d}y^{\star}}{\mathrm{d}x},$$

在 $x=1$ 处等于 $\frac{1}{2}\times(-\frac{3}{4})=-\frac{3}{8}$，两者相同。同样可算出 $\Phi'(0)=-6$；在 $x=2$ 处 $\partial_y F=0$，$v=0$，$\Phi'(2)=0$，这正是最小点。

第二项不能丢　这个例子里 $\nabla_{\boldsymbol{x}}F=0$。如果只对 F 求偏导，也就是把 y 固定住，得到的斜率处处是 0，结论将是 x 不用调整。图 28.9比较了这两条线。忽略响应项，求的是“固定内解时的偏导数”，并不是双层目标的导数。

28.1 双层问题
28.2 内层解映射
28.3 隐式微分
28.3.1 超梯度
28.3.2 线性方程求解
28.3.3 约束内层
28.4 迭代展开
28.5 单层重述
28.6 外层求解
28.7 本章小结

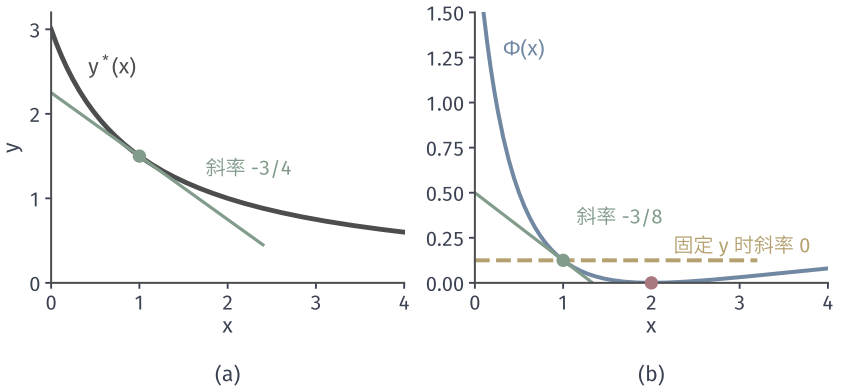


图 28.9 正则拟合例中 $x = 1$ 处的导数。(a) 内解曲线的切线，斜率是 $\mathrm{d}y^\star/\mathrm{d}x = -3/4$。(b)$\Phi$ 的切线（绿）斜率是超梯度 $-3/8$；黄色虚线是把 y 固定在 $y^\star(1)$ 时的外层函数，斜率为 0。红点是 Φ 的最小点。

与极小极大的联系 式 (28.16)也说明了表 28.1的最后一行。若 $F = -g$，内解处 $\nabla_{\boldsymbol{y}} F = -\nabla_{\boldsymbol{y}} g = \mathbf{0}$，于是 $\boldsymbol{v} = \mathbf{0}$，超梯度退化为 $\nabla_{\boldsymbol{x}} F$。内解的移动对外层值只有二阶影响，这就是第 27章和第 19章的包络关系。一般的双层问题没有这种抵消，响应项必须计算。

28.3.2 线性方程求解

d 很大时 $\boldsymbol{H}$ 存不下，更不用说求逆。本小节要解决的问题是：怎样只用 $\boldsymbol{H}$ 与向量的乘积解伴随方程，以及这个方程解得不准会造成多大的超梯度误差。

主要思想：只用矩阵—向量积 解 $\boldsymbol{H}\boldsymbol{v} = \nabla_{\boldsymbol{y}} F$ 的迭代法只需要反复计算 $\boldsymbol{H}\boldsymbol{u}$。这个乘积不需要 $\boldsymbol{H}$ 的元素，它是内层梯度沿 $\boldsymbol{u}$ 方向的方向导数：

$$\boldsymbol{H}\boldsymbol{u} = \frac{\mathrm{d}}{\mathrm{d}s} \nabla_{\boldsymbol{y}} g(\boldsymbol{x}, \boldsymbol{y} + s\boldsymbol{u})\Big|_{s=0}. \tag{28.17}$$

这称为Hessian 向量积（Hessian-vector product）。用自动求导时，它的代价是梯度计算的常数倍，也可以用内层梯度的差分近似。$\boldsymbol{B}^{\top}\boldsymbol{v}$ 同样如此，它是标量 $\langle \nabla_{\boldsymbol{y}} g, \boldsymbol{v} \rangle$（固定 $\boldsymbol{v}$）对 $\boldsymbol{x}$ 的梯度。

$\boldsymbol{H}$ 对称正定时，共轭梯度法是自然的选择，算法的推导可参考卷二第 15 章“Krylov 子空间法”。第 k 步用到的量都按下面的递推得到，$\alpha^{(k)}$ 和 $\beta^{(k)}$ 在本小节里表示共轭梯度法自己的系数：

$$\begin{aligned}\alpha^{(k)} &= \frac{\|\boldsymbol{r}^{(k)}\|_2^2}{\langle \boldsymbol{d}^{(k)}, \boldsymbol{H}\boldsymbol{d}^{(k)}\rangle}, \qquad \boldsymbol{v}^{(k+1)} = \boldsymbol{v}^{(k)} + \alpha^{(k)}\boldsymbol{d}^{(k)},\\ &\qquad \boldsymbol{r}^{(k+1)} = \boldsymbol{r}^{(k)} - \alpha^{(k)}\boldsymbol{H}\boldsymbol{d}^{(k)},\\ \beta^{(k)} &= \frac{\|\boldsymbol{r}^{(k+1)}\|_2^2}{\|\boldsymbol{r}^{(k)}\|_2^2}, \qquad \boldsymbol{d}^{(k+1)} = \boldsymbol{r}^{(k+1)} + \beta^{(k)}\boldsymbol{d}^{(k)}.\end{aligned} \tag{28.18}$$

计算过程　下面用二维内层走一遍全过程。内层是带二次惩罚的最小二乘，外层把结果和目标点比较：

$$g(x, \boldsymbol{y}) = \frac{1}{2}\|\boldsymbol{A}\boldsymbol{y} - \boldsymbol{b}\|_2^2 + \frac{x}{2}\|\boldsymbol{y}\|_2^2, \qquad F(\boldsymbol{y}) = \frac{1}{2}\|\boldsymbol{y} - \boldsymbol{c}\|_2^2.$$

数据取为

$$\boldsymbol{A} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}, \qquad \boldsymbol{b} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}, \qquad \boldsymbol{c} = \begin{bmatrix} 0 \\ 2 \end{bmatrix}.$$

变量

- 内解 $\boldsymbol{y} \in \mathbb{R}^d$，事先由内层算法得到。
- 伴随向量的迭代值 $\boldsymbol{v}^{(k)} \in \mathbb{R}^d$，残差 $\boldsymbol{r}^{(k)} = \nabla_{\boldsymbol{y}} F - \boldsymbol{H}\boldsymbol{v}^{(k)}$，搜索方向 $\boldsymbol{d}^{(k)} \in \mathbb{R}^d$。
- 超梯度估计 $\hat{\boldsymbol{\gamma}}^{(k)} \in \mathbb{R}^n$，把式 (28.16)中的 $\boldsymbol{v}$ 换成 $\boldsymbol{v}^{(k)}$ 得到。

初始化　先在当前 $\boldsymbol{x}$ 处得到内解，计算外层梯度，并置 $\boldsymbol{v}^{(0)} = \boldsymbol{0}$，$\boldsymbol{r}^{(0)} = \boldsymbol{d}^{(0)} = \nabla_{\boldsymbol{y}} F$。

例中取 $x = 1$。$\boldsymbol{H} = \boldsymbol{A}^{\top}\boldsymbol{A} + x\boldsymbol{I}$，解 $\boldsymbol{H}\boldsymbol{y} = \boldsymbol{A}^{\top}\boldsymbol{b}$ 得到内解，于是

$$\boldsymbol{H} = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}, \qquad \boldsymbol{y} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \qquad \boldsymbol{r}^{(0)} = \boldsymbol{y} - \boldsymbol{c} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

$\boldsymbol{H}$ 的两个特征值都为正，共轭梯度法适用。内层梯度对 x 的导数是 $\boldsymbol{y}$，所以 $\boldsymbol{B} = \boldsymbol{y}$，$\nabla_x F = 0$。

每轮更新

1. 计算 $\boldsymbol{H}\boldsymbol{d}^{(k)}$，按式 (28.18)得到 $\alpha^{(k)}$，更新 $\boldsymbol{v}$ 和 $\boldsymbol{r}$。

   例中第一轮，$\boldsymbol{H}\boldsymbol{d}^{(0)} = (1,-2)$，于是

   $$\alpha^{(0)} = \frac{2}{3}, \qquad \boldsymbol{v}^{(1)} = \frac{2}{3}\begin{bmatrix}1\\-1\end{bmatrix}, \qquad \boldsymbol{r}^{(1)} = \frac{1}{3}\begin{bmatrix}1\\1\end{bmatrix}.$$

   此时的超梯度估计是 $-\boldsymbol{y}^{\top}\boldsymbol{v}^{(1)} = 0$。

2. 按式 (28.18)计算 $\beta^{(k)}$，更新搜索方向。

   例中第一轮，

   $$\beta^{(0)} = \frac{2/9}{2} = \frac{1}{9}, \qquad \boldsymbol{d}^{(1)} = \frac{1}{3}\begin{bmatrix}1\\1\end{bmatrix} + \frac{1}{9}\begin{bmatrix}1\\-1\end{bmatrix} = \frac{2}{9}\begin{bmatrix}2\\1\end{bmatrix}.$$

   例中第二轮，先算矩阵—向量积和分母：

   $$\boldsymbol{H}\boldsymbol{d}^{(1)} = \frac{10}{9}\begin{bmatrix}1\\1\end{bmatrix}, \qquad \langle \boldsymbol{d}^{(1)}, \boldsymbol{H}\boldsymbol{d}^{(1)} \rangle = \frac{20}{27}.$$

   于是

   $$\alpha^{(1)} = \frac{2/9}{20/27} = \frac{3}{10}, \qquad \boldsymbol{v}^{(2)} = \frac{1}{5}\begin{bmatrix}4\\-3\end{bmatrix}, \qquad \boldsymbol{r}^{(2)} = \boldsymbol{0}.$$

3. 残差范数低于设定精度时停止，否则回到第 1 步。例中 $\boldsymbol{r}^{(2)} = \boldsymbol{0}$，两步结束。

   最终得到 $\boldsymbol{v} = (4/5, -3/5)$，由式 (28.16)，超梯度是

   $$\Phi'(1) = -\boldsymbol{y}^{\top}\boldsymbol{v} = -\frac{1}{5}.$$

   直接验证。由式 (28.13)，内解的导数是

   $$\frac{\mathrm{d}\boldsymbol{y}}{\mathrm{d}x} = -\boldsymbol{H}^{-1}\boldsymbol{y} = -\frac{1}{5}\begin{bmatrix}2\\1\end{bmatrix},$$

它与 $\nabla_{\boldsymbol{y}} F = (1,-1)$ 的内积是 $-1/5$，结果一致。第一轮的残差非零，超梯度估计是 0，没有反映出真实的下降方向。这引出了下面的误差分析。

共轭梯度法的前提　式 (28.18)的分母要求 $\langle \boldsymbol{d}, \boldsymbol{H}\boldsymbol{d} \rangle > 0$，这需要 $\boldsymbol{H}$ 正定。在局部极小点的分支上这成立，但内层非凸且当前点还没收敛时可能不成立。取 $\boldsymbol{H} = \mathrm{diag}(1,-1)$，$\boldsymbol{r}^{(0)} = (1,1)$，第一步的分母就是 $1 - 1 = 0$，算法

无法进行。这时应先检查所在位置是否还在所说的分支上，再选择适用于不定矩阵的求解方法。

线性残差怎样变成超梯度误差 设 $\tilde{\boldsymbol{v}}$ 是近似解，残差 $\boldsymbol{r} = \boldsymbol{H}\tilde{\boldsymbol{v}} - \nabla_{\boldsymbol{y}} F$。线性方程的残差很小，并不等于超梯度的误差很小，中间隔着 $\boldsymbol{H}^{-1}$ 和 $\boldsymbol{B}$。

定理 28.9 伴随残差的放大 设内解精确，$\boldsymbol{H} \succeq \mu \boldsymbol{I}$，$\tilde{\boldsymbol{\gamma}}$ 是把式 (28.16) 中的 $\boldsymbol{v}$ 换成 $\tilde{\boldsymbol{v}}$ 所得的估计，残差 $\boldsymbol{r} = \boldsymbol{H}\tilde{\boldsymbol{v}} - \nabla_{\boldsymbol{y}} F$。则

$$\|\tilde{\boldsymbol{\gamma}} - \nabla\Phi\|_2 \le \frac{\|\boldsymbol{B}\|_2}{\mu} \|\boldsymbol{r}\|_2. \tag{28.19}$$

证明 由残差的定义，$\tilde{\boldsymbol{v}} - \boldsymbol{v} = \boldsymbol{H}^{-1}\boldsymbol{r}$，所以

$$\tilde{\boldsymbol{\gamma}} - \nabla\Phi = -\boldsymbol{B}^{\top}(\tilde{\boldsymbol{v}} - \boldsymbol{v}) = -\boldsymbol{B}^{\top}\boldsymbol{H}^{-1}\boldsymbol{r}.$$

再用 $\|\boldsymbol{H}^{-1}\|_2 \le 1/\mu$ 取范数即得。 ■

上面例子的第一轮，$\|\boldsymbol{r}^{(1)}\|_2 = \sqrt{2}/3 \approx 0.471$，$\|\boldsymbol{B}\|_2 = \sqrt{2}$，$\boldsymbol{H}$ 的最小特征值是 $(5-\sqrt{5})/2 \approx 1.382$。代入式 (28.19)，上界约为 0.482，实际误差是 0.2。

式 (28.19) 说明，内层越病态，同样的残差放大得越厉害；而且病态也让共轭梯度法收敛更慢。图 28.10 中，$\kappa = 10$ 时残差很快下降，超梯度误差跟着下降；$\kappa = 1000$ 时残差下降缓慢，超梯度误差还比残差大几倍到几十倍。内层病态的问题需要把线性方程解得更准，这笔账要算进总成本。

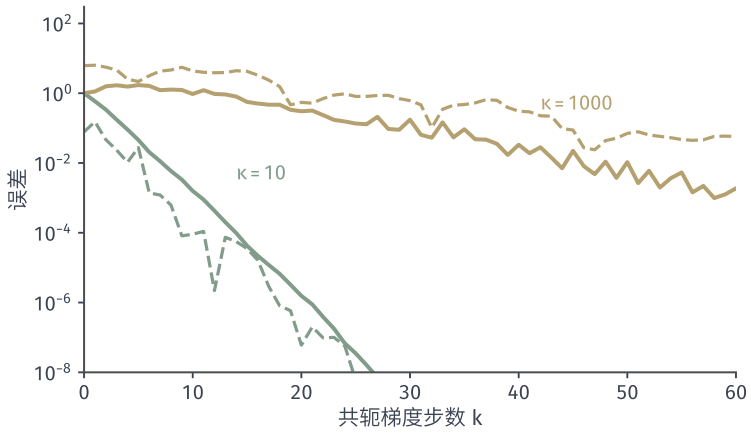


图 28.10 共轭梯度法解伴随方程的收敛，$d = 60$，$\boldsymbol{H}$ 的特征值在 $[1/\kappa, 1]$ 上对数均匀分布，$\boldsymbol{B}$、$\nabla_{\boldsymbol{y}} F$ 是固定种子下的随机单位向量。实线是残差范数，虚线是超梯度的绝对误差。绿色 $\kappa = 10$，黄色 $\kappa = 1000$。

28.1 双层问题
28.2 内层解映射
28.3 隐式微分
28.3.1 超梯度
28.3.2 线性方程求解
28.3.3 约束内层
28.4 迭代展开
28.5 单层重述
28.6 外层求解
28.7 本章小结

另一种近似：Neumann 级数 若 $0 < \alpha < 2/\lambda_{\max}(\boldsymbol{H})$，矩阵 $\boldsymbol{I} - \alpha\boldsymbol{H}$ 的谱半径小于 1，$\boldsymbol{H}^{-1}$ 可以展开为级数：

$$\boldsymbol{H}^{-1} = \alpha \sum_{k=0}^{\infty} (\boldsymbol{I} - \alpha \boldsymbol{H})^k. \tag{28.20}$$

只取前 ℓ 项，就得到一种只用 Hessian 向量积的近似。它收敛比共轭梯度法慢，但第 28.4.2小节会看到，它恰好就是截断展开的极限形式。

28.3.3 约束内层

内层有约束时，内解满足的不再是驻点方程，$\boldsymbol{H}$ 的位置也要换成整个 KKT 系统。本小节要解决的问题是：什么时候这样做是对的，以及哪些情况下根本不存在经典的导数。

主要思想：对活动的 KKT 方程求导 g 已用作内层目标，这里把内层约束写成 $c_i(\boldsymbol{x}, \boldsymbol{y}) \le 0$（$i = 1, \dots, m$）和 $h_j(\boldsymbol{x}, \boldsymbol{y}) = 0$（$j = 1, \dots, p$），Lagrange 函数是

$$\mathcal{L}(\boldsymbol{x}, \boldsymbol{y}, \boldsymbol{\lambda}, \boldsymbol{\nu}) = g + \sum_{i=1}^{m} \lambda_i c_i + \sum_{j=1}^{p} \nu_j h_j. \tag{28.21}$$

第 17章的 KKT 条件和第 19章的敏感性定理告诉我们：在基准 KKT 点处，若线性无关约束资格（LICQ）、严格互补和二阶充分条件成立，则存在邻域内的连续可微分支，活动集 A 在分支上保持不变，分支上的点都是严格局部极小点。

把活动不等式当成等式，记活动不等式与等式的总数为 $a + p$，定义四个矩阵。前两个是 $\mathcal{L}$ 的二阶导数：

$$\boldsymbol{W} = \nabla^2_{\boldsymbol{y}\boldsymbol{y}} \mathcal{L}, \qquad \boldsymbol{B}_{\mathcal{L}} = \nabla^2_{\boldsymbol{y}\boldsymbol{x}} \mathcal{L}.$$

另外两个来自约束：$\boldsymbol{J}$ 的行是活动约束和等式约束对 $\boldsymbol{y}$ 的梯度，$\boldsymbol{E}$ 的行是它们对 $\boldsymbol{x}$ 的梯度。KKT 矩阵为

$$\boldsymbol{K} = \begin{bmatrix} \boldsymbol{W} & \boldsymbol{J}^{\top} \\ \boldsymbol{J} & \boldsymbol{0} \end{bmatrix}. \tag{28.22}$$

定理 28.10　约束内层的隐式超梯度　设在基准 KKT 点处 g, c_i, h_j 二阶连续可微，LICQ、严格互补与二阶充分条件成立，F 连续可微。则 $\Phi(\boldsymbol{x}) = F(\boldsymbol{x}, \hat{\boldsymbol{y}}(\boldsymbol{x}))$ 在基准点附近连续可微，且

$$\nabla \Phi = \nabla_{\boldsymbol{x}} F - \boldsymbol{B}_{\mathcal{L}}^{\top} \boldsymbol{v} - \boldsymbol{E}^{\top} \boldsymbol{w}, \qquad \boldsymbol{K} \begin{bmatrix} \boldsymbol{v} \\ \boldsymbol{w} \end{bmatrix} = \begin{bmatrix} \nabla_{\boldsymbol{y}} F \\ \boldsymbol{0} \end{bmatrix}. \tag{28.23}$$

证明　由第 19章的不等式约束解导数定理，$\boldsymbol{K}$ 可逆，分支的 Jacobian 矩阵 $\boldsymbol{D}$ 与乘子导数 $\boldsymbol{D}_{\boldsymbol{w}}$ 满足

$$\boldsymbol{K} \begin{bmatrix} \boldsymbol{D} \\ \boldsymbol{D}_{\boldsymbol{w}} \end{bmatrix} = - \begin{bmatrix} \boldsymbol{B}_{\mathcal{L}} \\ \boldsymbol{E} \end{bmatrix}.$$

取 $(\boldsymbol{v}, \boldsymbol{w})$ 为式 (28.23)中方程的解，并用 $\boldsymbol{K}$ 对称，得到

$$\boldsymbol{D}^{\top} \nabla_{\boldsymbol{y}} F = \begin{bmatrix} \boldsymbol{D} \\ \boldsymbol{D}_{\boldsymbol{w}} \end{bmatrix}^{\top} \boldsymbol{K} \begin{bmatrix} \boldsymbol{v} \\ \boldsymbol{w} \end{bmatrix} = -\boldsymbol{B}_{\mathcal{L}}^{\top} \boldsymbol{v} - \boldsymbol{E}^{\top} \boldsymbol{w}.$$

代入第 28.3.1小节开头的链式法则即得。 ■

预算例　外层变量取预算 $x = \tau$，内层沿用第 19章的预算二次问题的主要部分，外层想让配置接近另一个点：

$$g(\boldsymbol{y}) = \tfrac{1}{2}(y_1 - 2)^2 + \tfrac{1}{2}(y_2 - 1)^2, \quad c(\tau, \boldsymbol{y}) = y_1 + y_2 - \tau \le 0,$$
$$F(\boldsymbol{y}) = \tfrac{1}{2}(y_1 - 2)^2 + \tfrac{1}{2}(y_2 - 2)^2.$$

在 $\tau = 2$ 处约束活动，内解和乘子是 $\boldsymbol{y} = (3/2, 1/2)$，$\lambda = 1/2 > 0$，严格互补成立。各块矩阵和右端为

$$\boldsymbol{W} = \boldsymbol{I}, \quad \boldsymbol{J} = \begin{bmatrix} 1 & 1 \end{bmatrix}, \quad \boldsymbol{B}_{\mathcal{L}} = \boldsymbol{0}, \quad E = -1, \quad \nabla_{\boldsymbol{y}} F = \begin{bmatrix} -1/2 \\ -3/2 \end{bmatrix}.$$

式 (28.23)的方程组写开是

$$v_1 + w = -\frac{1}{2}, \qquad v_2 + w = -\frac{3}{2}, \qquad v_1 + v_2 = 0.$$

前两式相加并用第三式，得 $w = -1$，于是 $v_1 = 1/2$，$v_2 = -1/2$。代入超梯度公式，

$$\Phi'(2) = -E\, w = -1.$$

28.1 双层问题
28.2 内层解映射
28.3 隐式微分
28.4 迭代展开
28.4.1 完整展开
28.4.2 截断展开
28.4.3 极限关系
28.5 单层重述
28.6 外层求解
28.7 本章小结

直接核对：约束活动时 $\boldsymbol{y} = ((1+\tau)/2, (\tau-1)/2)$，它对 τ 的导数是 $(1/2, 1/2)$，与 $\nabla_{\boldsymbol{y}} F$ 的内积是 -1。图 28.11(a) 的绿线是这条解路径。

公式失效的情形 活动集变化时导数会断。预算例中 $\lambda = (3-\tau)/2$，到 $\tau = 3$ 时乘子降为零，严格互补失效，内解停在理想点 $(2,1)$。外层值的左导数由 $(\tau-4)/2$ 给出，在 $\tau = 3$ 处等于 $-1/2$；$\tau > 3$ 时外层值是常数，右导数是 0。这就是图 28.11(b) 的折点，经典的导数在此不存在。

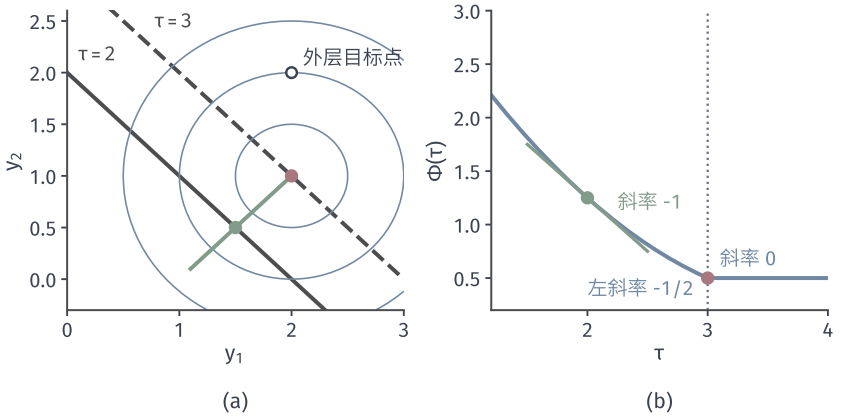


图 28.11 约束内层的预算例。(a) 蓝色等高线属于内层目标，红点是无约束最优 $(2,1)$，深灰实线和虚线分别是 $\tau = 2$ 和 $\tau = 3$ 的预算线，绿线是内解随 τ 移动的路径，绿点是 $\tau = 2$ 的解，空心点是外层目标点 $(2,2)$。(b) 外层值 $\Phi(\tau)$，绿色切线在 $\tau = 2$ 处斜率 -1；红点 $\tau = 3$ 处活动集改变，左斜率 $-1/2$，右斜率 0。

$\boldsymbol{K}$ 奇异时公式不能使用，但内解不一定不可微。取内层 $\min \frac{1}{2}(y-2)^2$，约束 $y \le \tau$ 和 $2y \le 2\tau$ 是同一条约束的两种写法。在 $\tau = 1$ 处两者都活动，$\boldsymbol{J}$ 的两行成比例，LICQ 失效，$\boldsymbol{K}$ 奇异，乘子也不唯一。而内解 $y = \min\{\tau, 2\}$ 在 $\tau = 1$ 附近的导数是 1，完全正常。

还有一种常见的错误，是把 $\boldsymbol{H}$ 换成 $\boldsymbol{W}$，仍用式 (28.16)。预算例中 $\boldsymbol{W} = \boldsymbol{I}$，$\boldsymbol{B}_{\mathcal{L}} = \boldsymbol{0}$，这样算出的解导数是零向量，而真实导数是 $(1/2, 1/2)$。约束的作用全在 $\boldsymbol{J}$ 和 $\boldsymbol{E}$ 里，只换一个矩阵等于把约束的响应丢掉了。

28.4 迭代展开

隐式微分依赖“内层已经到了解点”这一前提。如果真正运行的是有限步算法，也可以直接对算法的输出求导。于是要问：怎样对 $\boldsymbol{y}^{(T)}(\boldsymbol{x})$ 求导，这样算出的量和隐式导数有什么关系？这种做法称为**迭代展开**（unrolled differentiation）。

设内层的一步更新写成

$$\boldsymbol{y}^{(t+1)} = \boldsymbol{\Psi}_t(\boldsymbol{y}^{(t)}, \boldsymbol{x}), \qquad t = 0, \dots, T-1. \tag{28.24}$$

梯度下降取 $\boldsymbol{\Psi}_t = \boldsymbol{y} - \alpha \nabla_{\boldsymbol{y}} g$，这些更新规则本身的性质在第 6章讨论，下面只处理沿更新传播导数时新增的对象。

28.1 双层问题
28.2 内层解映射
28.3 隐式微分
28.4 迭代展开
28.4.1 完整展开
28.4.2 截断展开
28.4.3 极限关系
28.5 单层重述
28.6 外层求解
28.7 本章小结

28.4.1 完整展开

主要思想：把算法看成复合函数 $\boldsymbol{y}^{(T)}$ 是 $\boldsymbol{x}$ 经过 T 层复合得到的函数，对它求导只需要反复使用链式法则。图 28.12是 $T = 2$ 的计算图，$\boldsymbol{x}$ 进入每一步更新，所以每一层都要算一次它的影响。

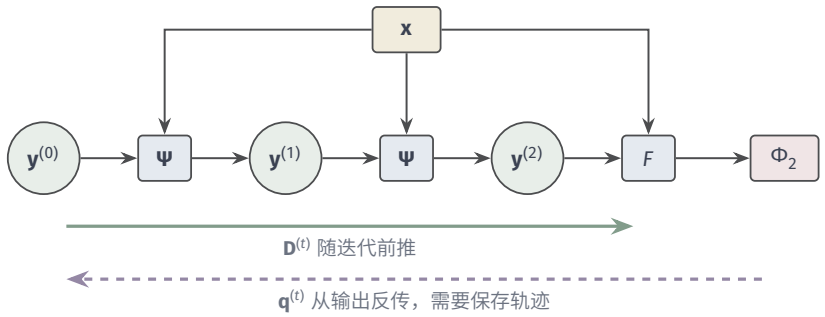


图 28.12 $T = 2$ 时的展开计算图。圆圈是内层状态，方框 $\boldsymbol{\Psi}$ 是一步更新，$\boldsymbol{x}$ 进入每步更新和外层目标。绿色实线表示前向传播 Jacobian 矩阵 $\boldsymbol{D}^{(t)}$，紫色虚线表示从外层往回传播向量 $\boldsymbol{q}^{(t)}$。

记 $\boldsymbol{D}^{(t)} \in \mathbb{R}^{d \times n}$ 为 $\boldsymbol{y}^{(t)}$ 对 $\boldsymbol{x}$ 的 Jacobian 矩阵，并记一步更新的两个偏导数：

$$\boldsymbol{A}^{(t)} = \frac{\partial \boldsymbol{\Psi}_t}{\partial \boldsymbol{y}} \in \mathbb{R}^{d \times d}, \qquad \boldsymbol{C}^{(t)} = \frac{\partial \boldsymbol{\Psi}_t}{\partial \boldsymbol{x}} \in \mathbb{R}^{d \times n}.$$

两者都在 $(\boldsymbol{y}^{(t)}, \boldsymbol{x})$ 处取值。对梯度下降，$\boldsymbol{A}^{(t)} = \boldsymbol{I} - \alpha \boldsymbol{H}^{(t)}$，$\boldsymbol{C}^{(t)} = -\alpha \boldsymbol{B}^{(t)}$，其中 $\boldsymbol{H}^{(t)}$、$\boldsymbol{B}^{(t)}$ 是在当前迭代点算出的二阶导数。

对式 (28.24)两边关于 $\boldsymbol{x}$ 求导。$\boldsymbol{y}^{(t)}$ 本身依赖 $\boldsymbol{x}$，所以

$$\boldsymbol{D}^{(t+1)} = \boldsymbol{A}^{(t)} \boldsymbol{D}^{(t)} + \boldsymbol{C}^{(t)}. \tag{28.25}$$

有限步目标的梯度由链式法则得到：

$$\nabla \Phi_T = \nabla_{\boldsymbol{x}} F + (\boldsymbol{D}^{(T)})^{\top} \nabla_{\boldsymbol{y}} F, \tag{28.26}$$

其中 F 的导数在 $(\boldsymbol{x}, \boldsymbol{y}^{(T)})$ 处取值。这是精确的导数，只不过它是 Φ_T 的导数。

主要思想：反向累积 式 (28.25)要带着一个 $d \times n$ 矩阵走完全程，n 很大时存不下。把递推展开，得到

$$\boldsymbol{D}^{(T)} = \sum_{t=0}^{T-1} \boldsymbol{A}^{(T-1)} \cdots \boldsymbol{A}^{(t+1)} \boldsymbol{C}^{(t)} + \boldsymbol{A}^{(T-1)} \cdots \boldsymbol{A}^{(0)} \boldsymbol{D}^{(0)}.$$

式 (28.26)只需要这个矩阵的转置与一个向量的乘积，可以从左边的向量开始依次向右乘。令 $\boldsymbol{q}^{(T)} = \nabla_{\boldsymbol{y}} F$，从 $t = T-1$ 到 0 计算

$$\boldsymbol{h} \leftarrow \boldsymbol{h} + (\boldsymbol{C}^{(t)})^{\top} \boldsymbol{q}^{(t+1)}, \qquad \boldsymbol{q}^{(t)} = (\boldsymbol{A}^{(t)})^{\top} \boldsymbol{q}^{(t+1)}. \tag{28.27}$$

$\boldsymbol{h}$ 的初值是 $\nabla_{\boldsymbol{x}} F$，循环结束后再加上 $(\boldsymbol{D}^{(0)})^{\top} \boldsymbol{q}^{(0)}$，结果就是 $\nabla \Phi_T$。

两种顺序保存的东西不同。前向传播保存 $\boldsymbol{D}^{(t)}$，不用保存轨迹。反向累积只保存向量，但 $\boldsymbol{A}^{(t)}$、$\boldsymbol{C}^{(t)}$ 要在 $\boldsymbol{y}^{(t)}$ 处计算，所以必须把整条轨迹保存下来，或者重新算出来。

计算过程 用正则拟合例在 $x = 0$ 处计算 $\Phi_3'(0)$, 内层取 $y^{(0)} = 0$, $\alpha = 1/2$。

变量

- 迭代点 $y^{(t)}$，前向时的导数 $D^{(t)}$，这里 $d = n = 1$，它们都是数。
- 一步更新的偏导数 $A^{(t)} = 1 - \alpha(1 + x)$，$C^{(t)} = -\alpha y^{(t)}$。
- 反向时的累积量 $q^{(t)}$ 和结果 h。

初始化 初值不依赖 x，所以 $D^{(0)} = 0$。例中 $x = 0$，于是 $A^{(t)} = 1/2$, $C^{(t)} = -y^{(t)}/2$。

每轮更新

1. 前向：更新 $y^{(t+1)}$，并按式 (28.25)更新 $D^{(t+1)}$。

   例中第一轮 $D^{(1)} = \frac{1}{2} \cdot 0 - \frac{1}{2} \cdot 0 = 0$，第二轮用 $y^{(1)} = 3/2$，第三轮用 $y^{(2)} = 9/4$，各轮结果为

$$y^{(1)}, y^{(2)}, y^{(3)} = \frac{3}{2}, \frac{9}{4}, \frac{21}{8}; \qquad D^{(1)}, D^{(2)}, D^{(3)} = 0, -\frac{3}{4}, -\frac{3}{2}.$$

2. 走完 T 步后由式 (28.26)得到梯度。

   例中 $\partial_y F = y^{(3)} - 1 = 13/8$，$\partial_x F = 0$，于是

$$\Phi_3'(0) = D^{(3)} \cdot \frac{13}{8} = -\frac{39}{16}.$$

28.1 双层问题
28.2 内层解映射
28.3 隐式微分
28.4 迭代展开
28.4.1 完整展开
28.4.2 截断展开
28.4.3 极限关系
28.5 单层重述
28.6 外层求解
28.7 本章小结

3. 反向：若改用反向累积，从 $q^{(3)}=13/8$、$h=0$ 开始按式 (28.27)回算。

例中 $t=2$ 时 $C^{(2)}=-9/8$，$t=1$ 时 $C^{(1)}=-3/4$，$t=0$ 时 $C^{(0)}=0$，各轮结果为

$$h:\ -\frac{117}{64},\ -\frac{156}{64},\ -\frac{156}{64};\qquad q^{(2)},q^{(1)},q^{(0)}=\frac{13}{16},\ \frac{13}{32},\ \frac{13}{64}.$$

最终 $h=-156/64=-39/16$，与前向结果相同。这个数是 Φ_3 的精确导数，而 Φ 的导数是 -6，两者相差很大，都是正确的导数，只是对应不同的目标。

初始化、动量与不可微更新 若初值依赖 $\boldsymbol{x}$，$\boldsymbol{D}^{(0)}$ 不为零，它的贡献必须保留。用上一轮解作热启动时，严格说初值也依赖过去的 $\boldsymbol{x}$，把这一项丢掉就是在计算另一个量的导数。

算法含动量时，一步更新依赖不止一个迭代点。例如重球法的更新是

$$\boldsymbol{y}^{(t+1)}=\boldsymbol{y}^{(t)}-\alpha\nabla_{\boldsymbol{y}}g+\omega(\boldsymbol{y}^{(t)}-\boldsymbol{y}^{(t-1)}),$$

要把 $\boldsymbol{z}^{(t)}=(\boldsymbol{y}^{(t)},\boldsymbol{y}^{(t-1)})$ 作为完整状态，式 (28.25)和式 (28.27)对 $\boldsymbol{z}$ 成立。只对 $\boldsymbol{y}$ 求导会漏掉上一步的影响。

邻近迭代的情况不同。第 11章的软阈值映射是分段光滑的，在分段的边界处没有经典导数，展开的公式只在迭代不落在边界上时才成立。

表 28.4比较两种传播顺序的代价，规模变量是内层维数 d、外层维数 n 和步数 T。反向累积的存储可以用**检查点**（checkpointing）减少：每隔 k 步保存一次状态，回算时从最近的检查点重算，$k\approx\sqrt{T}$ 时存储降到约 $\sqrt{T}$ 个状态，代价是多大约一倍的计算量。

做法	存储	每步主要运算
前向传播	$O(dn)$	n 次 Hessian 向量积
反向累积	$O(Td)$	一次 Hessian 向量积
隐式微分	$O(d)$	每次线性迭代一次积

表 28.4　三种超梯度计算的代价。存储只计迭代中保存的向量，隐式微分要求内层已解到解点附近，迭代次数由线性方程的精度决定。

28.4.2 截断展开

保存整条轨迹太贵时，常见的做法是只反传末尾 ℓ 步。这和少跑几步内层是两件不同的事。

两种缩短 第一种，把内层步数从 T 减到 T'。目标函数换成了 $\Phi_{T'}$，它的导数依然精确，只是目标变了。第二种，内层仍跑满 T 步，反向只回到 $t = T - \ell$，相当于在式 (28.27)中提前停止，并丢掉更早的响应。目标还是 Φ_T，算出的是它导数的近似。

定理 28.11 截断反传的误差 设 $\tilde{\boldsymbol{D}}$ 是把递推 (28.25)中 $\boldsymbol{D}^{(T-\ell)}$ 换成零后得到的矩阵。则

$$\|(\boldsymbol{D}^{(T)} - \tilde{\boldsymbol{D}})^{\top} \nabla_{\boldsymbol{y}} F\|_2 \le \Big\| \prod_{t=T-\ell}^{T-1} \boldsymbol{A}^{(t)} \Big\|_2 \|\boldsymbol{D}^{(T-\ell)}\|_2 \|\nabla_{\boldsymbol{y}} F\|_2 . \tag{28.28}$$

其中连乘按 t 从大到小自左向右排列。

证明 从第 $T-\ell$ 步开始展开递推，得到

$$\boldsymbol{D}^{(T)} = \sum_{t=T-\ell}^{T-1} \boldsymbol{A}^{(T-1)} \cdots \boldsymbol{A}^{(t+1)} \boldsymbol{C}^{(t)} + \boldsymbol{A}^{(T-1)} \cdots \boldsymbol{A}^{(T-\ell)} \boldsymbol{D}^{(T-\ell)} .$$

$\tilde{\boldsymbol{D}}$ 恰好是右端的求和部分，差就是第二项。转置、右乘 $\nabla_{\boldsymbol{y}} F$，再取范数即得。 ∎

内层是收缩迭代时，连乘随 ℓ 几何衰减，所以末尾的若干步已经包含了大部分信息。

正则拟合例中的比较 $x = 0$ 时 $A = 1/2$。取 $T = 20$，$y^{(t)}$ 已非常接近 3，$\partial_y F \approx 2$，只反传 ℓ 步得到的结果约为

$$-6\big(1 - 2^{-\ell}\big).$$

$\ell = 1$ 时约为 -3，$\ell = 3$ 时约为 -5.25。图 28.13(b) 中的绿线是这组值，黄线是真正只跑 $T = \ell$ 步的 $\Phi'_{\ell}(0)$，依次为 $0, -15/16, -39/16$ 等。两者随 ℓ 都趋向 -6，黄线要慢得多，因为它不仅少反传，还因内层没跑够而用错了 y。

28.1 双层问题
28.2 内层解映射
28.3 隐式微分
28.4 迭代展开
28.4.1 完整展开
28.4.2 截断展开
28.4.3 极限关系
28.5 单层重述
28.6 外层求解
28.7 本章小结

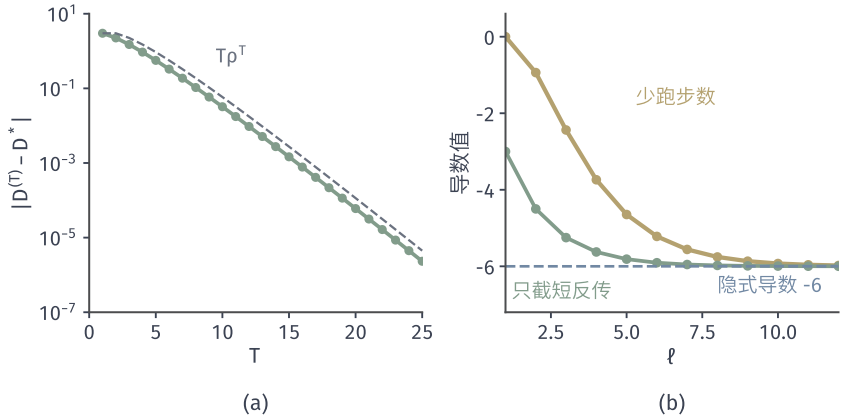


图 28.13 展开导数与隐式导数的关系，正则拟合例，$x = 0$，$\alpha = 1/2$。(a) 绿线是导数误差 $|D^{(T)} - D^{\star}| = 3(T+1)2^{-T}$，虚线是定理 28.12型的参考界。(b) 黄线是真实步数为 $T = \ell$ 的完整展开导数，绿线是 $T = 20$、只反传 ℓ 步的结果，蓝色虚线是隐式导数 -6。

截断后的向量一般不是 Φ_T 的梯度，也不保证是它的下降方向。设误差向量为 $\boldsymbol{e}$，真实梯度为 $\boldsymbol{\gamma}$。只有在 $\|\boldsymbol{e}\|_2 < \|\boldsymbol{\gamma}\|_2$ 时才能由

$$\langle \boldsymbol{\gamma} + \boldsymbol{e}, \boldsymbol{\gamma} \rangle \geq \|\boldsymbol{\gamma}\|_2 \big(\|\boldsymbol{\gamma}\|_2 - \|\boldsymbol{e}\|_2 \big) > 0$$

断定它仍是下降方向。

与隐式微分的联系 若内层已收敛，每一步的 $\boldsymbol{A}^{(t)}$、$\boldsymbol{C}^{(t)}$ 都等于解点处的值 $\boldsymbol{I} - \alpha \boldsymbol{H}$ 和 $-\alpha \boldsymbol{B}$，反传 ℓ 步给出

$$\nabla_{\boldsymbol{x}} F - \boldsymbol{B}^{\top} \Big[\alpha \sum_{k=0}^{\ell-1} (\boldsymbol{I} - \alpha \boldsymbol{H})^{k} \Big] \nabla_{\boldsymbol{y}} F .$$

方括号正是式 (28.20)的前 ℓ 项，所以截断反传相当于用 Neumann 级数的部分和代替 $\boldsymbol{H}^{-1}$。

28.4.3 极限关系

既然两种路线在内层收敛时形式一致，自然要问：$T \to \infty$ 时，展开的导数是否趋于隐式导数。答案是在收缩性等条件下成立，而只有迭代点收敛是不够的。

定理 28.12　展开导数的收敛　固定 $\boldsymbol{x}$，内层用梯度下降，步长 $\alpha \le 1/L_g$。设沿迭代路径和 $\boldsymbol{y}^\star$ 处有 $\mu \boldsymbol{I} \preceq \boldsymbol{H} \preceq L_g \boldsymbol{I}$，且存在常数 L_H, L_B，使这些点上 $\boldsymbol{H}$、$\boldsymbol{B}$ 关于 $\boldsymbol{y}$ 分别 L_H、L_B—Lipschitz。记

$$\rho = 1 - \alpha\mu, \qquad \boldsymbol{D}^\star = -\boldsymbol{H}_\star^{-1}\boldsymbol{B}_\star,$$
$$e_0 = \|\boldsymbol{y}^{(0)} - \boldsymbol{y}^\star\|_2, \qquad c = \alpha(L_H\|\boldsymbol{D}^\star\|_2 + L_B)e_0. \tag{28.29}$$

若迭代满足

$$\|\boldsymbol{y}^{(t)} - \boldsymbol{y}^\star\|_2 \le \rho^t e_0, \tag{28.30}$$

则

$$\|\boldsymbol{D}^{(T)} - \boldsymbol{D}^\star\|_2 \le \rho^T \|\boldsymbol{D}^{(0)} - \boldsymbol{D}^\star\|_2 + cT\rho^{T-1}. \tag{28.31}$$

证明　先说明 $\boldsymbol{D}^\star$ 是极限递推的不动点。把 $\boldsymbol{A}_\star = \boldsymbol{I} - \alpha\boldsymbol{H}_\star$、$\boldsymbol{C}_\star = -\alpha\boldsymbol{B}_\star$ 代入，得到

$$\boldsymbol{A}_\star\boldsymbol{D}^\star + \boldsymbol{C}_\star = \boldsymbol{D}^\star - \alpha\boldsymbol{H}_\star\boldsymbol{D}^\star - \alpha\boldsymbol{B}_\star = \boldsymbol{D}^\star.$$

记 $\boldsymbol{E}^{(t)} = \boldsymbol{D}^{(t)} - \boldsymbol{D}^\star$，用递推式减去不动点方程，并在中间加减 $\boldsymbol{A}^{(t)}\boldsymbol{D}^\star$，得到

$$\boldsymbol{E}^{(t+1)} = \boldsymbol{A}^{(t)}\boldsymbol{E}^{(t)} + (\boldsymbol{A}^{(t)} - \boldsymbol{A}_\star)\boldsymbol{D}^\star + (\boldsymbol{C}^{(t)} - \boldsymbol{C}_\star).$$

条件 $\alpha \le 1/L_g$ 使 $\boldsymbol{A}^{(t)}$ 的特征值落在 $[0, \rho]$，所以 $\|\boldsymbol{A}^{(t)}\|_2 \le \rho$。由 Lipschitz 条件和式 (28.30)，后两项的范数之和不超过 $c\rho^t$，于是

$$\|\boldsymbol{E}^{(t+1)}\|_2 \le \rho\|\boldsymbol{E}^{(t)}\|_2 + c\rho^t.$$

对 T 归纳。$T = 0$ 时式 (28.31)成立。若对 T 成立，代入上式，得到

$$\|\boldsymbol{E}^{(T+1)}\|_2 \le \rho^{T+1}\|\boldsymbol{E}^{(0)}\|_2 + cT\rho^T + c\rho^T = \rho^{T+1}\|\boldsymbol{E}^{(0)}\|_2 + c(T+1)\rho^T.$$

这就是 $T+1$ 时的结论。 ■

收缩率 ρ 控制衰减，多出的因子 T 来自迭代点误差在每一层的累积。把结果代入式 (28.26)，当 $\nabla_{\boldsymbol{x}} F$、$\nabla_{\boldsymbol{y}} F$ 关于 $\boldsymbol{y}$ 连续时，$\nabla\Phi_T \to \nabla\Phi$。

手算核对　正则拟合例在 $x = 0$ 处，$\mu = L_g = 1$，$\rho = 1/2$，$L_H = 0$，$L_B = 1$，$e_0 = 3$，$c = 3/2$，$\|D^{(0)} - D^\star\| = 3$。式 (28.31)的右端是 $3 \cdot 2^{-T} + 3T \cdot 2^{-T}$。

另一方面，对式 (28.11)直接求导，得到 $D^{(T)} = -3 + 3(T+1)2^{-T}$，误差恰好等于

$$|D^{(T)} - D^\star| = 3(T+1)2^{-T}.$$

上界在这个例子里取等号。

点列收敛不够 内层点列收敛这个事实本身，不足以交换求导与极限。设内层目标是 $g = \frac{1}{2}(y-x)^2$，$y^\star(x) = x$，某个带扰动的内层算法输出

$$y^{(T)}(x) = x + \frac{\sin(Tx)}{T}.$$

对所有 x，误差不超过 $1/T$，点列一致收敛到内解。可是 $\mathrm{d}y^{(T)}/\mathrm{d}x = 1 + \cos(Tx)$，在 $x = 0$ 处恒等于 2，而隐式导数是 1。误差的幅度在缩小，它的振荡频率却在增加，导数记录的恰恰是后者。定理 28.12用收缩和导数的 Lipschitz 条件排除了这种情形。

收缩一旦失去，结论也无从谈起。正则拟合例中 $\alpha = 1/2$ 时 $q = (1-x)/2$，$x \geq 3$ 时 $|q| \geq 1$，迭代不收敛，Φ_T 描述的是一个发散算法的输出。而且，固定的短展开并不自动给出真实双层目标的梯度：$T = 2$ 时的导数 $-15/16$ 与 -6 相差甚远。

28.1 双层问题
28.2 内层解映射
28.3 隐式微分
28.4 迭代展开
28.5 单层重述
28.5.1 最优性条件重述
28.5.2 值函数重述
28.6 外层求解
28.7 本章小结

28.5 单层重述

前两节都把 Φ 当作函数，靠内层求解和求导来下降。另一种思路是不把内层嵌套着解，而把“$\boldsymbol{y}$ 确实是内解”写成关于 $(\boldsymbol{x}, \boldsymbol{y})$ 的约束，然后一起最小化外层目标。接下来要弄清：这样的约束有哪些写法，每种写法保留了什么，又失去了什么？

对乐观模型，由式 (28.8)，这个想法可以直接实现。悲观模型不行：外层目标里夹着一个对解集的 sup，把它改成对 $\boldsymbol{y}$ 的联合最小化就等于把最坏情况换成了最好情况，它还需要再嵌套一层，不能套用下面的改写。本节只讨论乐观模型。

28.5.1 最优性条件重述

用 $\boldsymbol{y}$ 的最优性条件替代“$\boldsymbol{y} \in \boldsymbol{S}(\boldsymbol{x})$”是最直接的做法，内层有约束时这就是 KKT 条件。

写成一个单层问题 沿用式 (28.21)的记号，把乘子也作为变量，得到下面的问题：

$$\begin{aligned} \min_{\boldsymbol{x},\boldsymbol{y},\boldsymbol{\lambda},\boldsymbol{\nu}} \quad & F(\boldsymbol{x},\boldsymbol{y}) \\ \text{s.t.} \quad & \boldsymbol{x}\in\boldsymbol{C},\quad \nabla_{\boldsymbol{y}}\mathcal{L}=\boldsymbol{0},\quad \boldsymbol{h}=\boldsymbol{0}, \\ & \boldsymbol{c}\le\boldsymbol{0},\quad \boldsymbol{\lambda}\ge\boldsymbol{0},\quad \lambda_i c_i=0,\ i=1,\dots,m. \end{aligned} \tag{28.32}$$

含有 $\lambda_i c_i = 0$ 这样的约束的问题称为**互补约束规划**（mathematical program with complementarity constraints），简称 MPCC。

这样的改写要成立，必须保证 KKT 条件恰好刻画内层的全局解。KKT 条件一般只是局部解的必要条件，下面的定理给出能作此替换的情形。

定理 28.13 凸内层的 KKT 重述 设对每个 $\boldsymbol{x}\in\boldsymbol{C}$，$g(\boldsymbol{x},\cdot)$ 和 $c_i(\boldsymbol{x},\cdot)$ 凸且连续可微，$h_j(\boldsymbol{x},\cdot)$ 仿射，内层满足 Slater 条件。则对每个 $\boldsymbol{x}\in\boldsymbol{C}$，

$$\boldsymbol{y}\in\boldsymbol{S}(\boldsymbol{x}) \iff \text{存在}(\boldsymbol{\lambda},\boldsymbol{\nu})\text{使}(\boldsymbol{x},\boldsymbol{y},\boldsymbol{\lambda},\boldsymbol{\nu})\text{满足式 (28.32)的约束.} \tag{28.33}$$

于是 $(\boldsymbol{x},\boldsymbol{y})$ 是乐观模型的全局解，当且仅当存在乘子使 $(\boldsymbol{x},\boldsymbol{y},\boldsymbol{\lambda},\boldsymbol{\nu})$ 是式 (28.32)的全局解。

证明 固定 $\boldsymbol{x}$。凸问题的 KKT 点是全局解，这给出“⇐”；Slater 条件下凸问题的全局解满足 KKT 条件，乘子存在，这给出“⇒”。这两个结论见第 17章和第 18章。两个问题的目标都只含 $(\boldsymbol{x},\boldsymbol{y})$，可行点的 $(\boldsymbol{x},\boldsymbol{y})$ 分量又相同，所以全局解的 $(\boldsymbol{x},\boldsymbol{y})$ 分量也相同。 ■

定理只对应全局解。局部解的对应要复杂得多：式 (28.32)的局部解固定了一组乘子，而原问题要比较所有乘子对应的邻近点，乘子不唯一时两者可以不一致。相关反例的构造较长，读者可查阅双层规划的专门文献。

非凸内层的反例 内层非凸时，KKT 点可能根本不是全局解。取无约束内层和外层

$$g(y)=\frac{1}{4}y^4-\frac{1}{2}y^2,\qquad F(y)=\frac{1}{2}y^2.$$

驻点方程 $y^3-y=0$ 的解是 $y\in\{-1,0,1\}$。全局解是 $y=\pm1$，外层值是 $1/2$。可是重述问题只要求驻点方程，它会选 $y=0$，外层值是 0，而 $y=0$ 恰好是内层的局部极大点。

一个凸内层的例子 取内层 $\min_y \frac{1}{2}(y-x)^2$，约束 $y\ge0$，也就是 $c=-y\le0$。外层目标取 $F=\frac{1}{2}(x+1)^2+\frac{1}{2}(y-1)^2$。内层的 KKT 条件是

$$y-x-\lambda=0,\qquad y\ge0,\qquad \lambda\ge0,\qquad \lambda y=0.$$

互补条件把可行集分成两支。$\lambda = 0$ 时 $y = x \geq 0$；$y = 0$ 时 $\lambda = -x \geq 0$。这就是图 28.14(b) 的折线，$y^\star(x) = \max\{x, 0\}$。

在两支上分别求解。沿 $y = x$，$x \geq 0$，外层值是 $x^2 + 1$，最小值是 $x = 0$ 处的 1。沿 $y = 0$，$x \leq 0$，外层值是 $\frac{1}{2}(x+1)^2 + \frac{1}{2}$，最小值是 $x = -1$ 处的 $\frac{1}{2}$。全局解是 $(x, y) = (-1, 0)$。

互补约束为什么难 图 28.14(a) 画出了 $a \geq 0$、$b \geq 0$、$ab = 0$ 的可行集，它由两条半轴组成，没有内部，在原点还拐了一个直角。一般非线性规划算法依靠约束资格，而这类可行集恰好破坏它们。

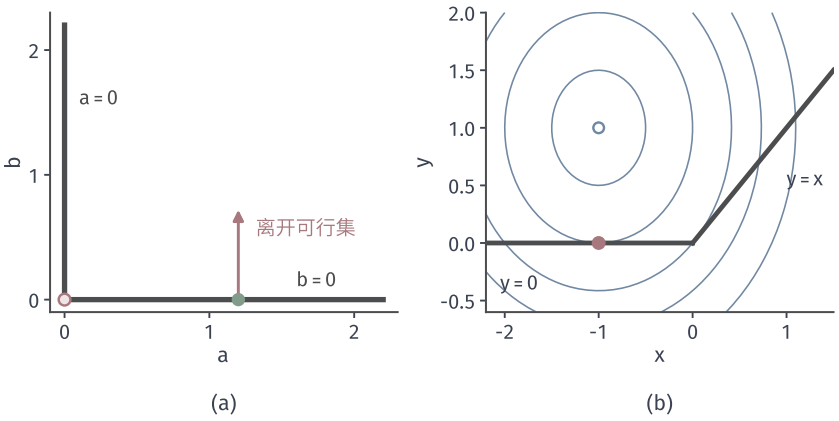


图 28.14 互补约束的几何。(a)$a \geq 0$、$b \geq 0$、$ab = 0$ 的可行集是两条半轴。在绿点处，严格满足不等式 $b \geq 0$ 的方向（红箭头）立刻离开可行集；原点处（空心点）拐角使等式约束的梯度为零。(b) 内层 $\min \frac{1}{2}(y - x)^2$，$y \geq 0$ 的解图像（深灰折线），蓝色是外层等高线，空心点是外层的无约束最小点 $(-1, 1)$，红点是双层问题的解 $(-1, 0)$。

引理 28.14 互补约束破坏 MFCQ 设 $m \geq 1$。式 (28.32)的每个可行点都不满足 Mangasarian—Fromovitz 约束资格（MFCQ）。

证明 MFCQ 要求等式约束的梯度线性无关，并存在方向 $\boldsymbol{d}$，使它与所有等式约束的梯度正交，且与所有活动不等式约束的梯度内积为负。考虑某一对约束 $\lambda_i \geq 0$、$c_i \leq 0$、$e = \lambda_i c_i = 0$，在全部变量构成的空间中，等式的梯度是

$$\nabla e = c_i \nabla \lambda_i + \lambda_i \nabla c_i.$$

若 $\lambda_i > 0$，$c_i = 0$，则 $\nabla e = \lambda_i \nabla c_i$。$c_i \leq 0$ 活动，MFCQ 要求 $\langle \nabla c_i, \boldsymbol{d} \rangle < 0$，于是 $\langle \nabla e, \boldsymbol{d} \rangle < 0$，与正交矛盾。

28.1 双层问题
28.2 内层解映射
28.3 隐式微分
28.4 迭代展开
28.5 单层重述
28.5.1 最优性条件重述
28.5.2 值函数重述
28.6 外层求解
28.7 本章小结

若 $\lambda_i = 0$，$c_i < 0$，则 $\nabla e = c_i \nabla \lambda_i$。$-\lambda_i \le 0$ 活动，MFCQ 要求 $\langle \nabla \lambda_i, \boldsymbol{d} \rangle > 0$，于是 $\langle \nabla e, \boldsymbol{d} \rangle < 0$，同样矛盾。

若 $\lambda_i = c_i = 0$，则 $\nabla e = \mathbf{0}$，等式约束的梯度线性相关。三种情形穷尽了可行点的所有可能。 ■

所以即使内层是凸的，也不能把一般非线性规划的收敛结论直接搬过来，那些结论通常要求某种约束资格。实践中的做法有两类：内层约束不多时枚举互补的分支，每一支是一个正常的问题，但分支数最多是 2^m；或者把 $\lambda_i c_i = 0$ 松弛成 $-\lambda_i c_i \le t$，让 t 逐渐趋于零，松弛问题有内部，但收敛到的点要回到原问题核对。

28.5.2 值函数重述

最优性条件的重述要靠凸性才能表达全局最优。另一种写法直接比较目标值，不需要内层的结构。

直接比较内层目标值 定义内层最优值函数

$$V(\boldsymbol{x}) = \inf_{\boldsymbol{y} \in \boldsymbol{Y}(\boldsymbol{x})} g(\boldsymbol{x}, \boldsymbol{y}). \tag{28.34}$$

$\boldsymbol{y}$ 是内解，当且仅当它内层可行，且它的内层目标值达到了最优值。

引理 28.15 值函数重述 设 $V(\boldsymbol{x})$ 有限。则

$$\boldsymbol{y} \in \boldsymbol{S}(\boldsymbol{x}) \iff \boldsymbol{y} \in \boldsymbol{Y}(\boldsymbol{x}) \text{且} g(\boldsymbol{x}, \boldsymbol{y}) \le V(\boldsymbol{x}). \tag{28.35}$$

证明 若 $\boldsymbol{y} \in \boldsymbol{S}(\boldsymbol{x})$，则 $\boldsymbol{y}$ 可行且 $g(\boldsymbol{x}, \boldsymbol{y}) = V(\boldsymbol{x})$。反过来，$\boldsymbol{y}$ 可行时必有 $g(\boldsymbol{x}, \boldsymbol{y}) \ge V(\boldsymbol{x})$，再加上不等式 $g(\boldsymbol{x}, \boldsymbol{y}) \le V(\boldsymbol{x})$，就得到等号，所以 $\boldsymbol{y}$ 取得内层最小值。 ■

引理没有用到任何凸性，所以全局选解这个要求被完整地写了下来。乐观模型因而等价于

$$\min_{\boldsymbol{x} \in \boldsymbol{C},\, \boldsymbol{y} \in \boldsymbol{Y}(\boldsymbol{x})} F(\boldsymbol{x}, \boldsymbol{y}) \quad \text{s.t.} \quad g(\boldsymbol{x}, \boldsymbol{y}) - V(\boldsymbol{x}) \le 0.$$

用正则拟合例计算 把式 (28.5)代入 g 并化简，得到

$$V(x) = \frac{9x}{2(1+x)}.$$

g 对 y 是二次函数，二次项系数为 $(1+x)/2$，所以

$$g(x,y) - V(x) = \frac{1+x}{2}\big(y - y^\star(x)\big)^2.$$

约束 $g - V \le 0$ 迫使 $y = y^\star(x)$，确实把内解曲线重新写了出来。V 的导数可以用包络关系求，

$$V'(x) = \partial_x g(x, y^\star(x)) = \frac{1}{2}(y^\star)^2 = \frac{9}{2(1+x)^2},$$

它和直接求导的结果相同。

两个困难　第一，V 可能不光滑。式 (28.15)的内层有 $V(x) = -|x|$，在切换点 $x = 0$ 处有折点，如图 28.15(a)。一般地，V 是一族函数的下确界，切换解的地方就会出现折点。计算 V 本身也要解一次内层问题。

第二，约束本身是退化的。在 $\boldsymbol{y} \in \boldsymbol{Y}(\boldsymbol{x})$ 上总有 $g - V \ge 0$，所以不存在严格满足 $g - V < 0$ 的点，Slater 条件永远不成立。上面的例子里更明显：约束函数 $\frac{1+x}{2}(y - y^\star)^2$ 在可行点处的梯度是零向量，它提供不了任何关于如何回到可行集的一阶信息。

松弛之后要重新核对　常见的处理是把约束放宽成 $g - V \le \varepsilon$，$\varepsilon > 0$。这样可行集有了内部，但代价是允许了不是内解的点。

正则拟合例中，$\varepsilon = 0.1$ 时可行集成了内解曲线周围的一条带，它的半宽是 $\sqrt{2\varepsilon/(1+x)}$，见图 28.15(b)。外层目标在 $y = 1$ 处取最小值 0，带子与直线 $y = 1$ 相交的部分全部是松弛问题的解。令 $u = 1 + x$，条件是

$$(u - 3)^2 \le 0.2\,u.$$

解得 $u \in [2.319, 3.881]$，即 $x \in [1.319, 2.881]$。真实的解 $x = 2$ 只是其中一点，松弛让最优解从一个点变成了一个区间，最优值也可能偏低。

28.1 双层问题
28.2 内层解映射
28.3 隐式微分
28.4 迭代展开
28.5 单层重述
28.6 外层求解
28.6.1 内层误差
28.6.2 导数误差
28.6.3 外层误差
28.7 本章小结

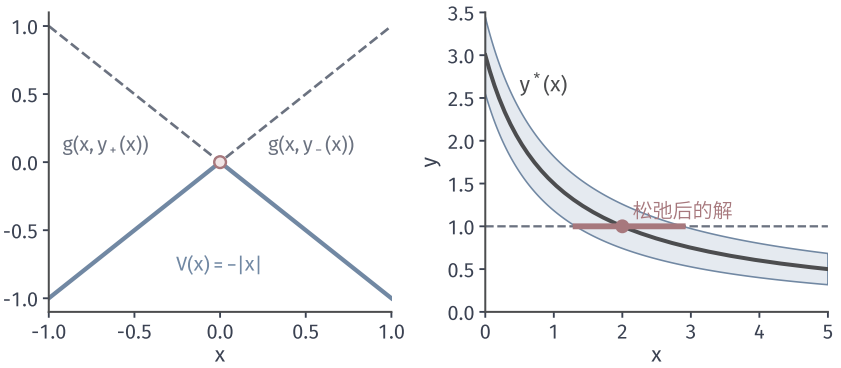


图 28.15 值函数重述的两个困难。(a) 式 (28.15)的最优值函数 $V(x) = -|x|$（蓝），虚线是沿两条分支的内层值，切换点（空心点）处 V 不可微。(b) 正则拟合例的松弛 $g - V \le 0.1$：浅蓝带是松弛后的可行集，深灰线是内解，红色线段是带子与 $y = 1$ 的交集，即松弛问题的全部最优解；红点是原问题的解 $x = 2$。

罚函数也可以用，把 $\rho(g - V)$ 加进外层目标。有限的 ρ 得到的通常只是近似解。不论松弛还是惩罚，得到的点都要重新检查：内层最优间隙 $g - V$ 有多大，它对应的内解距离有多大，以及改变 ε 或 ρ 后解是否稳定。

表 28.5比较两种重述。

	KKT 重述	值函数重述
全局等价	需凸性与约束资格	不需要
新增变量	乘子	无
主要困难	互补约束	V 的计算与不光滑
约束资格	MFCQ 处处失效	Slater 永不成立

表 28.5 乐观模型的两种单层重述。悲观模型不能这样改写。

28.6 外层求解

有了超梯度，外层就可以用前面各章的方法：$\boldsymbol{C}$ 是简单集合时用投影梯度（第 21章），变量多而问题光滑时用拟牛顿法（第 8章），Φ 有折点时用非光滑方法（第 11章）。选择之前先要确定优化的是哪个目标：真实选解的 Φ，还是有限步的 Φ_T。

超梯度带着偏差时，外层能保证什么？若把带固定偏差的超梯度当成精确梯度，收敛结论就不成立了。下面按内层、导数、外层的顺序逐级核算。

28.1 双层问题
28.2 内层解映射
28.3 隐式微分
28.4 迭代展开
28.5 单层重述
28.6 外层求解
28.6.1 内层误差
28.6.2 导数误差
28.6.3 外层误差
28.7 本章小结

28.6.1 内层误差

内层算法停下时，手里是一个近似解 $\hat{\boldsymbol{y}}$。这个点离内解有多远，可以用三个量来描述，它们含义不同，需要的计算条件也不同。

三种度量 固定 $\boldsymbol{x}$，记所选内解为 $\boldsymbol{y}^\star$，定义

$$\delta = g(\boldsymbol{x}, \hat{\boldsymbol{y}}) - g(\boldsymbol{x}, \boldsymbol{y}^\star), \qquad r = \|\nabla_{\boldsymbol{y}} g(\boldsymbol{x}, \hat{\boldsymbol{y}})\|_2, \qquad d = \|\hat{\boldsymbol{y}} - \boldsymbol{y}^\star\|_2.$$

δ 是内层目标差距，要知道最优值才能算。r 是驻点残差，随手可算。d 是到所选解的距离，通常没法直接算，而超梯度的误差恰恰取决于它。三者只有在特定条件下才能互相控制。

引理 28.16 强凸下的互控 设对固定的 $\boldsymbol{x}$，$\mu \boldsymbol{I} \preceq \nabla^2_{\boldsymbol{yy}} g \preceq L_g \boldsymbol{I}$ 处处成立。则

$$\mu d \le r \le L_g d, \tag{28.36}$$

$$\frac{\mu}{2} d^2 \le \delta \le \frac{L_g}{2} d^2, \tag{28.37}$$

$$\frac{r^2}{2L_g} \le \delta \le \frac{r^2}{2\mu}. \tag{28.38}$$

证明 记 $\phi = g(\boldsymbol{x}, \cdot)$，$\boldsymbol{e} = \hat{\boldsymbol{y}} - \boldsymbol{y}^\star$。由 $\nabla \phi(\boldsymbol{y}^\star) = \boldsymbol{0}$ 和积分形式的中值定理，

$$\nabla \phi(\hat{\boldsymbol{y}}) = \bar{\boldsymbol{H}} \boldsymbol{e},$$

其中 $\bar{\boldsymbol{H}}$ 是 Hessian 沿线段的平均，特征值在 $[\mu, L_g]$ 内，这给出式 (28.36)。

由 Taylor 公式，

$$\delta = \frac{1}{2} \boldsymbol{e}^\top \tilde{\boldsymbol{H}} \boldsymbol{e},$$

$\tilde{\boldsymbol{H}}$ 的特征值同样在 $[\mu, L_g]$ 内，这给出式 (28.37)。

由强凸性，

$$\phi(\boldsymbol{y}^\star) \ge \phi(\hat{\boldsymbol{y}}) - rd + \frac{\mu}{2} d^2 \ge \phi(\hat{\boldsymbol{y}}) - \frac{r^2}{2\mu},$$

第二步是对 d 取最小，这给出式 (28.38)的右半。对左半，从 $\hat{\boldsymbol{y}}$ 走一步梯度下降 $\hat{\boldsymbol{y}} - \nabla \phi(\hat{\boldsymbol{y}})/L_g$，由下降引理，函数值至少下降 $r^2/(2L_g)$，而它不会低于 $\phi(\boldsymbol{y}^\star)$。 ■

28.1 双层问题
28.2 内层解映射
28.3 隐式微分
28.4 迭代展开
28.5 单层重述
28.6 外层求解
28.6.1 内层误差
28.6.2 导数误差
28.6.3 外层误差
28.7 本章小结

条件去掉会怎样 图 28.16对比了强凸的 $g = y^2/2$ 和平坦的 $g = y^4/4$。对后者，$r = d^3$，$\delta = d^4/4$。当 $d = 0.1$ 时，残差只有 10^{-3}，目标差距只有 2.5×10^{-5}，看上去已经收敛得很好，到解的距离却还有 0.1。

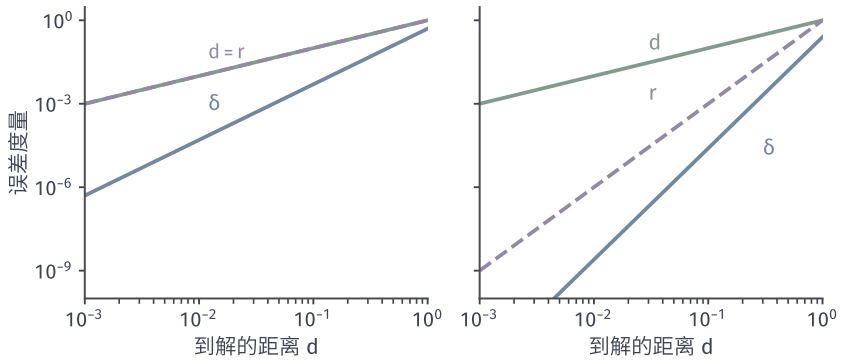


图 28.16 三种内层误差度量随距离 d 的变化，双对数坐标。(a) 强凸的 $g = y^2/2$：残差 r（紫色虚线）与 d（绿）重合，目标差距 δ（蓝）是 $d^2/2$。(b) 平坦的 $g = y^4/4$：$r = d^3$，$\delta = d^4/4$，残差和目标差距都远小于到解的距离。

非凸时情况更糟。$r = 0$ 只说明是驻点，它可能是极大点或鞍点。即使是极小点，d 也必须对着“所选解”算：δ 和 r 再小，也无法说明算法是否在正确的那个碗里。

热启动的得失 外层变化不大时，内层从上一轮解继续，可以省去大量迭代，这是热启动的好处。第 28.2.2小节也展示了它的代价：它会一直追踪同一条局部分支，穿过切换点也不察觉。热启动减少重复求解，但不能免除全局选解的核对；内层非凸时，需要定期从不同初值重解内层，比较内层目标值。

28.6.2 导数误差

超梯度的误差有几个来源：内解没解准，所有二阶导数都算在错误的点上；伴随方程没解准；或者反传被截断。它们对外层方向的影响要分开看。

两项误差的分解 记 $\hat{\boldsymbol{H}}$、$\hat{\boldsymbol{B}}$ 是在 $\hat{\boldsymbol{y}}$ 处计算的矩阵，$\boldsymbol{f}(\boldsymbol{y}) = \nabla_{\boldsymbol{y}} F(\boldsymbol{x}, \boldsymbol{y})$，并简写 $\hat{\boldsymbol{f}} = \boldsymbol{f}(\hat{\boldsymbol{y}})$、$\boldsymbol{f}_\star = \boldsymbol{f}(\boldsymbol{y}^\star)$。设 $\tilde{\boldsymbol{v}}$ 是伴随方程的近似解，残差和超梯度估计分别是

$$\boldsymbol{r}_{\boldsymbol{v}} = \hat{\boldsymbol{H}}\tilde{\boldsymbol{v}} - \hat{\boldsymbol{f}}, \qquad \hat{\boldsymbol{\gamma}} = \nabla_{\boldsymbol{x}} F(\boldsymbol{x}, \hat{\boldsymbol{y}}) - \hat{\boldsymbol{B}}^{\top}\tilde{\boldsymbol{v}}. \tag{28.39}$$

定理 28.17　超梯度误差的分解　固定 $\boldsymbol{x}$，设在 $\boldsymbol{y}^\star$ 和 $\hat{\boldsymbol{y}}$ 之间：$\boldsymbol{H}\succeq\mu\boldsymbol{I}$，$\|\hat{\boldsymbol{B}}\|_2\le M_B$，$\|\boldsymbol{f}_\star\|_2\le M_F$；$\nabla_{\boldsymbol{x}}F$、$\nabla_{\boldsymbol{y}}F$ 关于 $\boldsymbol{y}$ 是 L_F—Lipschitz 的，$\boldsymbol{H}$、$\boldsymbol{B}$ 关于 $\boldsymbol{y}$ 分别是 L_H、L_B—Lipschitz 的。记 $d=\|\hat{\boldsymbol{y}}-\boldsymbol{y}^\star\|_2$。则

$$\|\hat{\boldsymbol{\gamma}}-\nabla\Phi(\boldsymbol{x})\|_2\le C_d\,d+\frac{M_B}{\mu}\|\boldsymbol{r}_{\boldsymbol{v}}\|_2, \tag{28.40}$$

其中常数为

$$C_d=L_F+\frac{L_BM_F}{\mu}+\frac{M_B}{\mu}\Big(L_F+\frac{L_HM_F}{\mu}\Big). \tag{28.41}$$

证明　记 $\boldsymbol{v}^\star=\boldsymbol{H}_\star^{-1}\boldsymbol{f}_\star$，由 $\boldsymbol{H}_\star\succeq\mu\boldsymbol{I}$ 得 $\|\boldsymbol{v}^\star\|_2\le M_F/\mu$。在 $\boldsymbol{B}$ 的差上加减一项，把误差拆成三部分：

$$\begin{aligned}\hat{\boldsymbol{\gamma}}-\nabla\Phi&=\big[\nabla_{\boldsymbol{x}}F(\boldsymbol{x},\hat{\boldsymbol{y}})-\nabla_{\boldsymbol{x}}F(\boldsymbol{x},\boldsymbol{y}^\star)\big]\\&\quad-(\hat{\boldsymbol{B}}-\boldsymbol{B}_\star)^{\top}\boldsymbol{v}^\star-\hat{\boldsymbol{B}}^{\top}(\tilde{\boldsymbol{v}}-\boldsymbol{v}^\star).\end{aligned}$$

前两部分的范数分别不超过 L_Fd 和 L_BM_Fd/μ。第三部分要估计 $\tilde{\boldsymbol{v}}-\boldsymbol{v}^\star$。由残差的定义和 $\boldsymbol{f}_\star=\boldsymbol{H}_\star\boldsymbol{v}^\star$，得到

$$\hat{\boldsymbol{H}}(\tilde{\boldsymbol{v}}-\boldsymbol{v}^\star)=\boldsymbol{r}_{\boldsymbol{v}}+(\hat{\boldsymbol{f}}-\boldsymbol{f}_\star)-(\hat{\boldsymbol{H}}-\boldsymbol{H}_\star)\boldsymbol{v}^\star.$$

两边乘 $\hat{\boldsymbol{H}}^{-1}$ 并取范数，得到

$$\|\tilde{\boldsymbol{v}}-\boldsymbol{v}^\star\|_2\le\frac{1}{\mu}\Big(\|\boldsymbol{r}_{\boldsymbol{v}}\|_2+L_Fd+\frac{L_HM_F}{\mu}d\Big).$$

再乘 $\|\hat{\boldsymbol{B}}\|_2\le M_B$，三部分相加即得式 (28.40)。 ■

右端第一项由内层距离 d 负责，第二项由伴随残差负责，两者互不替代。只把 d 压小而不解准伴随方程，或者反过来，都会停在另一项决定的误差水平上。迭代展开时第二项换成式 (28.28)的截断误差。这些结论都要有相应的稳定性条件：μ 变小，所有系数都变大；$\boldsymbol{H}$ 奇异时上界不成立。

手算一次　正则拟合例在 $x=1$ 处，$y^\star=3/2$，$\Phi'(1)=-3/8$。设内层只解到 $\hat{y}=1.4$，$d=0.1$，这时 $\hat{H}=2$，$\hat{B}=1.4$，$\partial_yF=0.4$。伴随方程精确解是 $\hat{v}=0.2$，超梯度估计和误差分别是

$$\hat{\gamma}=-0.28,\qquad|\hat{\gamma}-\Phi'(1)|=0.095.$$

28.1 双层问题
28.2 内层解映射
28.3 隐式微分
28.4 迭代展开
28.5 单层重述
28.6 外层求解
28.6.1 内层误差
28.6.2 导数误差
28.6.3 外层误差
28.7 本章小结

若再把伴随方程解错，取 $\tilde{v}=0.15$，残差是 $r_v=2\times0.15-0.4=-0.1$，则

$$\tilde{\gamma}=-0.21,\qquad |\tilde{\gamma}-\Phi'(1)|=0.165.$$

代入式(28.41)。这里 $L_F=L_B=1$, $L_H=0$, $\mu=2$, $M_F=1/2$, $M_B=1.4$，所以 $C_d=1.95$，式(28.40)的右端是

$$1.95\times0.1+0.7\times0.1=0.265.$$

它确实是 0.165 的上界。

用数值实验看两项 图 28.17用一个 $d=30$ 的正则最小二乘内层，同时改变内层步数 K 和共轭梯度步数 k。(a) 中 k 固定时，增加 K 只能把误差压到某个平台，平台高度由 k 决定。(b) 中 K 固定时，增加 k 也只能压到由 K 决定的平台。两个旋钮要一起拧，单独加大其中一个是浪费。

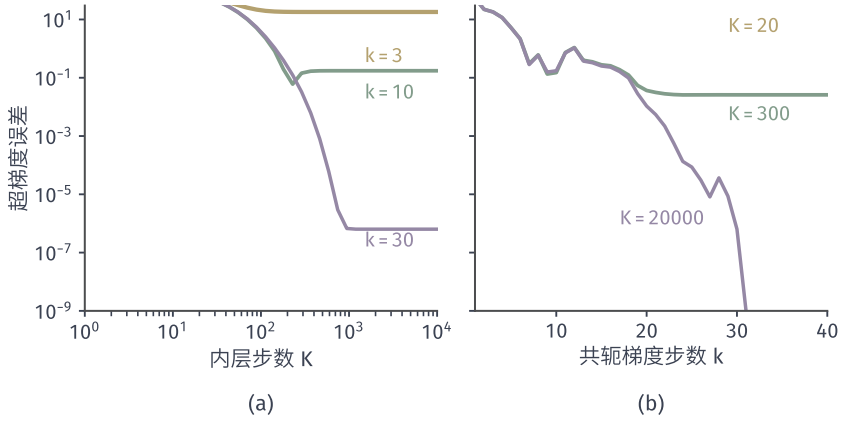


图 28.17 超梯度误差的两个来源。内层是 $d=30$ 的正则最小二乘，$x=0.05$，$\kappa\approx48$，数据由固定种子生成；内层用从零出发的梯度下降，步长 $1/L_g$，伴随方程用共轭梯度法。(a) 固定 $k=3,10,30$，误差随内层步数 K 的变化。(b) 固定 $K=20,300,20000$，误差随共轭梯度步数 k 的变化。

28.6.3 外层误差

最后把内层和导数的误差接到外层。本小节要解决的问题是：外层迭代用的是有偏差的超梯度，最终能保证什么，以及什么时候应该停下。

主要思想：偏差决定下限 外层最简单的情形是无约束的梯度下降，用带误差 $\boldsymbol{e}^{(t)}$ 的估计代替真实梯度：

$$\hat{\boldsymbol{\gamma}}^{(t)}=\nabla\Phi(\boldsymbol{x}^{(t)})+\boldsymbol{e}^{(t)}.$$

下面的定理说明，偏差会直接进入驻定精度。

定理 28.18　带误差的外层梯度下降　设 Φ 有下界 $\Phi_{\inf}$，梯度在含迭代点的区域上 L_Φ—Lipschitz。迭代

$$\boldsymbol{x}^{(t+1)} = \boldsymbol{x}^{(t)} - \frac{1}{L_\Phi}\hat{\boldsymbol{\gamma}}^{(t)} \tag{28.42}$$

满足

$$\min_{0\le t<T} \|\nabla\Phi(\boldsymbol{x}^{(t)})\|_2^2 \le \frac{2L_\Phi\big(\Phi(\boldsymbol{x}^{(0)}) - \Phi_{\inf}\big)}{T} + \frac{1}{T}\sum_{t=0}^{T-1}\|\boldsymbol{e}^{(t)}\|_2^2. \tag{28.43}$$

证明　记 $\boldsymbol{\gamma} = \nabla\Phi(\boldsymbol{x}^{(t)})$，$\hat{\boldsymbol{\gamma}} = \boldsymbol{\gamma} + \boldsymbol{e}$，略去上标。由下降引理，

$$\Phi(\boldsymbol{x}^{(t+1)}) \le \Phi(\boldsymbol{x}^{(t)}) - \frac{1}{L_\Phi}\langle \boldsymbol{\gamma}, \hat{\boldsymbol{\gamma}}\rangle + \frac{1}{2L_\Phi}\|\hat{\boldsymbol{\gamma}}\|_2^2.$$

利用恒等式

$$2\langle \boldsymbol{\gamma}, \hat{\boldsymbol{\gamma}}\rangle = \|\boldsymbol{\gamma}\|_2^2 + \|\hat{\boldsymbol{\gamma}}\|_2^2 - \|\boldsymbol{e}\|_2^2,$$

$\|\hat{\boldsymbol{\gamma}}\|_2^2$ 项正好抵消，得到

$$\Phi(\boldsymbol{x}^{(t+1)}) \le \Phi(\boldsymbol{x}^{(t)}) - \frac{1}{2L_\Phi}\|\boldsymbol{\gamma}\|_2^2 + \frac{1}{2L_\Phi}\|\boldsymbol{e}\|_2^2.$$

对 t 从 0 到 $T-1$ 求和，用 $\Phi(\boldsymbol{x}^{(T)}) \ge \Phi_{\inf}$，两边乘 $2L_\Phi/T$，再用最小值不超过平均值即得。 ■

若偏差始终约为 ε，式 (28.43)右端第二项约为 ε^2，不随 T 减小，这个上界只能保证 $\|\nabla\Phi\|_2$ 降到 ε 的量级。要得到收敛，内层精度必须随外层进展提高，比如让 $\sum_t \|\boldsymbol{e}^{(t)}\|_2^2$ 有限，这时第二项按 $1/T$ 衰减。

这正对应图 28.18。正则拟合例取 $\eta = 1$，从 $x^{(0)} = 1$ 出发，内层跑固定的 K 步后代入隐式公式。$K = 2$ 时迭代收敛到 $x = 5/3$，这里 $\hat{y} = 1$，估计的超梯度为零，真实梯度却是 $-27/512$。K 增大时偏差缩小但不消失，只有 K 随 t 增长时才收敛到 $x = 2$。

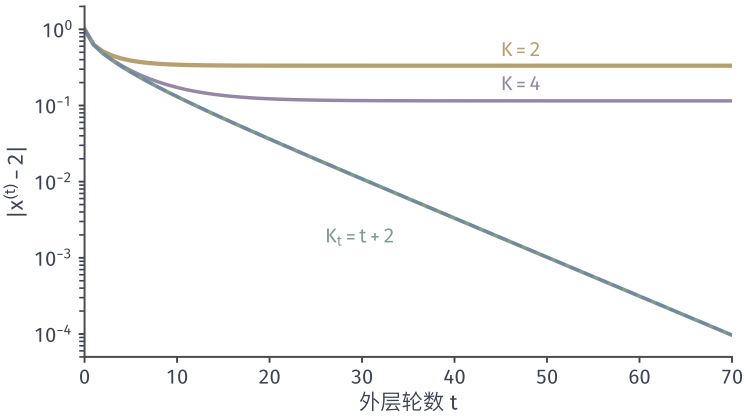


图 28.18　外层迭代误差 $|x^{(t)} - 2|$，正则拟合例，外层步长 $\eta = 1$，$x^{(0)} = 1$，内层每轮从 $y^{(0)} = 0$ 跑 K 步后用隐式公式。黄线 $K = 2$、紫线 $K = 4$ 停在偏差决定的平台，绿线 $K_t = t + 2$ 与精确内解（蓝色虚线）几乎重合，持续收敛。

计算过程　把整个外层循环在这个例子上走几轮，内层步数取 $K_t = t + 2$。

变量

- 外层迭代点 $x^{(t)}$，外层步长 η。
- 内层输出 $\hat{y}$，内层残差 $r = (1 + x)\hat{y} - 3$。
- 伴随解 v，超梯度估计 $\hat{\gamma}$。

初始化　例中 $x^{(0)} = 1$，$\eta = 1$。正则拟合例在 $x \geq 1$ 上 $|\Phi''| \leq 15/16$，步长 $\eta = 1$ 略小于 $1/L_\Phi = 16/15$，定理 28.18的证明同样适用，只需把 L_Φ 换成 $1/\eta$。

每轮更新

1. 内层从 $y^{(0)} = 0$ 运行 K_t 步，由式 (28.11)得到 $\hat{y}$，并记录残差 r。

   例中第一轮 $x = 1$，$q = 0$，$\hat{y} = 3/2$，残差为 0。

2. 解伴随方程，由式 (28.39)得到超梯度估计。

   例中 $H = 1 + x$，$\partial_y F = \hat{y} - 1$，$B = \hat{y}$，第一轮的结果是

$$v = \frac{\hat{y} - 1}{1 + x} = \frac{1}{4}, \qquad \hat{\gamma} = -\hat{y} v = -\frac{3}{8}.$$

3. 更新外层变量：$x^{(t+1)} = x^{(t)} - \eta\hat{\gamma}$。

   例中第一轮得到 $x^{(1)} = 11/8 = 1.375$。后面几轮的数值见表 28.6。

t	K_t	$x^{(t)}$	$\hat{y}$	r	$\hat{\gamma}$	Φ'
0	2	1.0000	1.5000	0.0000	−0.3750	−0.3750
1	3	1.3750	1.2715	0.0198	−0.1453	−0.1400
2	4	1.5203	1.1849	−0.0137	−0.0869	−0.0899
3	5	1.6072	1.1536	0.0077	−0.0680	−0.0665
4	6	1.6752	1.1197	−0.0044	−0.0501	−0.0509

表 28.6　正则拟合例的外层循环，$\eta = 1$，内层步数 $K_t = t + 2$。最后一列是在当前 $x^{(t)}$ 处的真实超梯度。

最终 $x^{(t)}$ 趋于 $x = 2$。表中 $\hat{\gamma}$ 与真实导数的差随内层残差缩小，这就是定理 28.17所说的情况。

报告什么、何时停止　外层的停止不能只看损失曲线，下面四项要分别检查，其中任何一项不达标都不能得出结论。

- 外层可行性：$\boldsymbol{x} \in \boldsymbol{C}$ 是否成立，$\boldsymbol{x}$ 是否在 $\operatorname{dom} \boldsymbol{S}$ 内，也就是内层确实有解。
- 外层驻定：有约束时用投影梯度的残差，无约束时用 $\|\hat{\boldsymbol{\gamma}}\|_2$，并以估计的偏差为基准；$\|\hat{\boldsymbol{\gamma}}\|_2$ 低于偏差水平时继续迭代已没有依据。
- 内层误差：驻点残差或目标差距；非凸时再比较不同初值下的内层目标值。
- 导数误差：伴随残差或截断长度，并可用 Φ 的中心差分抽查几个方向，差分时内层要解得足够准。

成本核算　总成本要把四个部分分开算。设外层跑 T_{o} 轮，每轮内层 K 步、共轭梯度 k 步，内层梯度的成本记作一个单位，Hessian 向量积是它的常数倍。隐式微分的总计算量约是 $T_{\mathrm{o}}(K + ck)$ 个单位，c 是这个常数倍数，存储是 $O(d)$。反向展开的计算量约是 $cT_{\mathrm{o}}K$，存储变成 $O(Kd)$，用检查点可以再压缩。内层病态时 K 和 k 都要增大，这是这类方法最主要的成本。

局部结论与全局结论　定理 28.18只保证驻定，而 Φ 一般是非凸的。即使内层对 y 强凸、外层对 y 凸，Φ 也可能非凸：正则拟合例有

$$\Phi''(x) = \frac{27 - 6u}{u^4}, \qquad u = 1 + x,$$

在 $x > 7/2$ 时为负。内层非凸时问题更严重，第 28.2.2小节的例子中 Φ 还会跳变。所以局部收敛的结果，加上驻定残差很小，都不能自动说成整个双层问题的全局最优。要作全局的声明，需要多初值搜索或问题本身的结构，并如实说明已检查的范围。

28.1 双层问题
28.2 内层解映射
28.3 隐式微分
28.4 迭代展开
28.5 单层重述
28.6 外层求解
28.7 本章小结

28.7 本章小结

双层优化的外层目标要读取一次优化的结果。本章首先分清三种对象：内解唯一时的 Φ，多解时靠规则确定的 Φ_{o} 和 Φ_{p}，以及运行有限步算法得到的 Φ_T。乐观模型在紧性和连续性下有解，悲观模型没有同样的保证，算法的隐含择解不自动等于其中任何一种。内层无解的 $\boldsymbol{x}$ 要排除，不能使用算法在那里给出的数字。

对解映射，Hessian 正定给出局部的可微分支，全局强凸才让分支代表唯一的内解。驻点 Jacobian 可逆只保证有驻点分支，不保证是极小点；内解唯一也不保证可微。非凸内层的全局选解可能跳变，外层目标跟着不连续，算法沿分支算出的导数穿过切换点后就不再描述全局选解。

求导有两条路线。隐式微分在解点处解一个伴随方程，得到 $\nabla\Phi = \nabla_{\boldsymbol{x}} F - \boldsymbol{B}^{\top}\boldsymbol{v}$，第二项是内解的响应，内层病态时线性残差被 $1/\mu$ 放大；约束内层要解 KKT 系统，活动集变化、严格互补失效或 KKT 矩阵奇异时这个公式不能用。迭代展开对算法输出求导，得到的是 Φ_T 的精确导数，反向累积省去大矩阵但要保存轨迹，截断反传则是导数的近似。

两条路线的关系由定理 28.12回答：内层一致收缩且二阶导数 Lipschitz 时，展开导数以 $T\rho^{T}$ 的速率趋于隐式导数；只有点列收敛不够，固定的短展开也不是真实目标的梯度。

单层重述把内层最优性变成约束。KKT 重述在凸内层和约束资格下全局等价，但产生的互补约束使 MFCQ 处处失效；值函数重述不需要凸性，代价是 V 可能不光滑、约束退化，松弛后要重新核对等价性。悲观模型不能这样改写。

表 28.7按误差来源归纳要核对的内容。外层收敛的曲线只回答了最后一行，其余各行需要各自的证据；局部驻定也不等于全局最优。

误差来源	度量	控制手段
内层求解	δ、r、d	增加内层步数
内层选解	不同初值的内层值	重解，勿仅靠热启动
伴随或截断	$\|\boldsymbol{r}_{\boldsymbol{v}}\|_2$、$\ell$	增加线性迭代或反传长度
外层	驻定残差、可行性	增加轮数，内层精度递增

表 28.7　双层求解中需要分别核对的四类误差。

第八部分

泛函优化

Functional Optimization

阅读指引

最后一部分的未知量不再是有限维向量，而是整个函数：连接两点的曲线中哪一条最短，满足边界条件的函数中哪一个能量最小。有限维的工具需要逐项重新检验。

第 29章先说明极小值的存在依赖函数空间的选择和目标的弱下半连续性，再用泛函的变分建立最优性条件，最后研究积分型目标以及怎样用有限维问题去近似它。

29.1 泛函优化问题
29.2 极小值的存在
29.3 泛函的微分
29.4 最优解的判别
29.5 积分泛函
29.6 有限维近似
29.7 本章小结

第 29 章

泛函优化

连接平面上两点的曲线，哪一条最短？一根两端固定的细线，自身有张力，又被弹簧拉向横轴，静止时是什么形状？这两个问题的答案都不是几个数，而是一整条曲线。前面各章的未知量是 $\mathbb{R}^n$ 中的向量，这里的未知量是函数，要比较的量是函数的一个数值读数，这个读数称为泛函。

把区间切成 n 段，曲线就成了由各结点高度组成的向量，问题回到有限维。函数可以看成 $n \to \infty$ 时的向量，泛函的梯度对应向量的梯度，积分对应求和。这个类比贯穿全章，也有几处不再成立，而这几处正是本章的重点。

有限维的工作顺序是先确认解存在，再用导数判别候选，最后计算。本章也按这个顺序走，每一步都要重新检查。闭球不再紧，所以存在性要换一种收敛来论证。同一个泛函放在不同的函数空间里，可微性可以不同，梯度也可以不同。局部极小依赖范数，二阶导数处处为正也可能保证不了局部极小。

第 29.1节写清目标、空间和边界约束。第 29.2节用最小化序列证明存在性，并逐条拆掉条件看它怎样失败。第 29.3节定义泛函的微分和梯度，第 29.4节用它们判别最优解。第 29.5节把这些工具用到积分形式的目标上，得到微分方程和边界条件。第 29.6节回到计算，用有限维问题近似原问题，并区分近似过程中的几种误差。

29.1 泛函优化问题

当未知量是一个函数时，一个优化问题要写清哪些东西？我们从两个具体目标出发，先把它们看成很长的向量上的优化，再说明目标、函数空间和边界约束各自规定了什么。

两个目标　考虑区间 $[0,1]$ 上的函数 u，要求它过两个固定端点：

$$u(0) = 0, \qquad u(1) = 1. \tag{29.1}$$

第一个目标是曲线 $y = u(x)$ 的长度：

$$\ell(u) = \int_0^1 \sqrt{1 + u'(x)^2}\,\mathrm{d}x. \tag{29.2}$$

第二个目标是一根细线的能量：

$$E(u) = \int_0^1 \Big(\frac{1}{2}u'(x)^2 + \frac{1}{2}u(x)^2\Big)\,\mathrm{d}x. \tag{29.3}$$

u'^2 一项惩罚倾斜，它希望曲线尽量平直；u^2 一项是弹簧的拉力，它希望曲线靠近横轴。两端的约束又不许曲线贴着横轴走，最优形状是两者的折中。式 (29.3)将贯穿全章。

候选函数不同，这两个数也不同。对 $u(x) = x$ 和 $u(x) = x^2$ 逐项积分，得到

$$\ell(x) = \sqrt{2} \approx 1.4142, \qquad \ell(x^2) = \frac{\sqrt{5}}{2} + \frac{1}{4}\operatorname{arcsinh} 2 \approx 1.4789,$$

以及

$$E(x) = \frac{1}{2} + \frac{1}{6} = \frac{2}{3}, \qquad E(x^2) = \frac{2}{3} + \frac{1}{10} = \frac{23}{30}.$$

直线在这两个目标下都比抛物线好。直线是不是这两个目标下的最好选择，现在还回答不了。

函数是很长的向量 怎样把函数放进前面各章的框架？取 $\Delta = 1/n$，结点 $x_i = i\Delta$，只记录结点高度 $u_i = u(x_i)$，$i = 0, \dots, n$。图 29.1中的绿色竖线就是这些坐标。两端的 $u_0 = 0$ 和 $u_n = 1$ 已被约束固定，自由的坐标是 $u_1, \dots, u_{n-1}$。

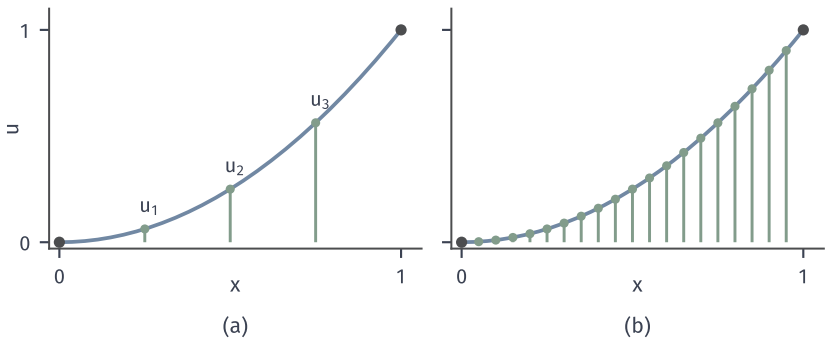


图 29.1 函数 $u(x) = x^2$ 的结点值。灰色点是被端点约束固定的值，绿色竖线是自由坐标。(a)$n = 4$，自由坐标 u_1, u_2, u_3。(b)$n = 20$，自由坐标有 19 个。切得越细，向量越长，曲线的形状也记录得越完整。

用差商代替导数，用求和代替积分，式 (29.3)变成一个普通的多元函数。其中 u'^2 一项写成

$$\int_0^1 \frac{1}{2}u'(x)^2\,\mathrm{d}x \approx \sum_{i=0}^{n-1} \frac{\Delta}{2}\Big(\frac{u_{i+1}-u_i}{\Delta}\Big)^2 = \frac{1}{2\Delta}\sum_{i=0}^{n-1}(u_{i+1}-u_i)^2.$$

这是自由坐标的二次函数。取 $n=2$，唯一的自由坐标是 u_1。对 u^2 一项用梯形求积，得到一元二次函数

$$E_2(u_1) = u_1^2 + (1-u_1)^2 + \frac{1}{4}u_1^2 + \frac{1}{8}.$$

令导数 $2u_1 - 2(1-u_1) + \frac{1}{2}u_1$ 为零，解出 $u_1 = 4/9 \approx 0.444$。这是用一个坐标对曲线中点高度的估计。

对应关系可以列成一张表，它只是起点，更多的对应要到后面几节才能建立。

表 29.1 向量与函数的对应关系。

向量 $\boldsymbol{x}\in\mathbb{R}^n$	函数 u
下标 i	位置 x
坐标 x_i	取值 $u(x)$
求和 $\sum_i x_i y_i$	积分 $\int u(x)v(x)\,\mathrm{d}x$
目标函数 $f(\boldsymbol{x})$	目标泛函 $J(u)$
线性约束的解集	固定边界值的函数集

这个类比能直接告诉我们该问什么，却不能直接给出答案。n 变大时维数没有上限，有限维里“维数固定”才成立的结论都要重新检查。

问题的写法 有了具体例子，就可以写出一般形式。函数虽然被看成向量，写法上不加粗，可行集仍记作 $\boldsymbol{C}$。

定义 29.1 泛函优化问题 设 X 是实赋范空间，$\boldsymbol{C}\subseteq X$ 非空，$J:\boldsymbol{C}\to\mathbb{R}\cup\{+\infty\}$，且至少有一点取有限值。把输入函数、输出实数的 J 称为**目标泛函**（objective functional），问题

$$\min_{u\in\boldsymbol{C}} J(u) \tag{29.4}$$

称为**泛函优化问题**（functional optimization problem）。记 $J^\star = \inf_{u\in\boldsymbol{C}} J(u)$。若 $u^\star\in\boldsymbol{C}$ 使 $J(u^\star)=J^\star$，称 $u^\star$ 为**最优解**。

这里的**泛函**（functional）指定义在函数集合上、取值为数的映射。有限维问题只要写目标和约束，因为 $\mathbb{R}^n$ 上的范数彼此等价，谈“附近”时

不用说明用哪个范数。函数问题多出一项要写：空间 X 及其范数。它规定了三件事：哪些函数算候选，目标在哪里有限，两个函数怎样才算接近。

选择函数空间　以 E 为例比较三个候选空间。若取 $X = C^1[0,1]$，后面会看到极小化序列可能跑出这个空间；此外 E 用到的是导数的平方积分，它并不是 C^1 范数。若取 $X = L^2(0,1)$，空间很大，但多数函数没有平方可积的导数，E 只能取 $+\infty$，端点值也没有意义，因为改变函数在一点的值不改变 L^2 中的元素。

合适的选择是让目标所用的量正好被范数控制，也就是取 Sobolev 空间

$$H^1(0,1) = \{u \in L^2(0,1) : u' \in L^2(0,1)\}, \qquad \|u\|_{H^1}^2 = \|u\|_2^2 + \|u'\|_2^2. \tag{29.5}$$

其中 u' 是弱导数。$H^1(0,1)$ 是 Hilbert 空间，式 (29.3)的 E 恰好等于 $\frac{1}{2}\|u\|_{H^1}^2$。

下面要用到这个空间的三条性质。第一，每个 $u \in H^1(0,1)$ 有连续代表，$u(y) - u(x) = \int_x^y u'(t)\,\mathrm{d}t$，所以端点值有意义。第二，点值受范数控制：

$$|u(y)| \le \sqrt{2}\,\|u\|_{H^1}, \qquad y \in [0,1]. \tag{29.6}$$

因此读取一点的值是 $H^1(0,1)$ 上的连续线性泛函，在 L^2 中则不连续。第三，记端点为零的子空间为 $H_0^1(0,1)$，其上有 Poincaré 不等式 $\|v\|_2 \le \|v'\|_2$。这些结论的证明可参考卷四第 21 章“Sobolev 空间”。

允许怎样改变候选　在 $X = H^1(0,1)$ 中，端点条件 (29.1)给出可行集

$$\boldsymbol{C} = \{u \in H^1(0,1) : u(0) = 0,\ u(1) = 1\}. \tag{29.7}$$

它不是线性子空间：两个可行函数的和在 $x = 1$ 处等于 2。但两个可行函数的差在两端都为零。取 $u_0(x) = x$，于是

$$\boldsymbol{C} = u_0 + \boldsymbol{V}, \qquad \boldsymbol{V} = H_0^1(0,1). \tag{29.8}$$

这与线性方程组 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 的解集写成特解加零空间 $\boldsymbol{x}_0 + \operatorname{null}\boldsymbol{A}$ 完全相同。两个端点条件相当于两条线性约束，子空间 $\boldsymbol{V}$ 只比 $H^1(0,1)$ 少两个方向，但它仍是无限维的。

图 29.2画了几个可行候选和它们与 u_0 的差。候选彼此差别很大，但 (b) 中所有的差都在两端归零。今后把这样的差称为扰动，记作 η。求最优解时只能沿 $\boldsymbol{V}$ 中的方向改变候选，这是第 29.4节最优性条件的出发点。

29.1 泛函优化问题
29.2 极小值的存在
29.3 泛函的微分
29.4 最优解的判别
29.5 积分泛函
29.6 有限维近似
29.7 本章小结

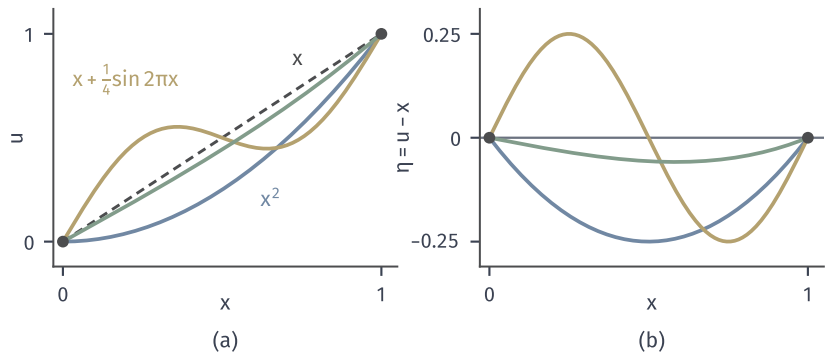


图 29.2　固定端点下的候选与扰动。(a) 过 $(0,0)$ 与 $(1,1)$ 的候选：灰色虚线 $u_0 = x$、蓝色 x^2、黄色 $x + \frac{1}{4}\sin 2\pi x$，绿色是 $\sinh x / \sinh 1$。(b) 同样颜色的三个差 $\eta = u - x$，它们都在端点为零，属于方向子空间 $\boldsymbol{V} = H_0^1(0,1)$。

约束不同，允许的扰动也不同。若只固定 $u(1) = 1$ 而放开 $u(0)$，扰动在 $x = 0$ 处可以取任意值，方向多了一个。若要求曲线处处不低于一个给定函数 ψ，某些位置只能向上改动，能走的方向就依赖当前的候选。可行方向的这些差别，后面都会反映到最优性条件里。

29.2 极小值的存在

不解任何方程，怎样断定一个泛函优化问题有解？这件事比有限维更需要先做，因为后面的最优性条件都以“设 $u^\star$ 是极小点”开头，极小点若不存在，由条件解出的东西就没有意义。

有限维的论证在哪里断开　第 1章的论证是：取一个最小化序列，让它通过三关。序列要留得住，极限要合法，比较要能传到极限。在 $\mathbb{R}^n$ 中，有界序列总有收敛子列，第一关由强制性和紧性解决。

无限维中这一步断开了。取 $L^2(0,1)$ 中的函数 $e_k(x) = \sqrt{2}\sin(k\pi x)$，$k = 1, 2, \ldots$。它们两两正交，长度都是 1，于是

$$\|e_j - e_k\|_2 = \sqrt{2} \qquad (j \neq k).$$

这个序列在单位闭球内，任意两项的距离却始终是 $\sqrt{2}$，没有 Cauchy 子列，也就没有范数收敛的子列。有界闭集不再紧。

换一种看极限的方式　图 29.3(a) 的 e_k 越摆越快，但摆动的正负会相互抵消。若固定一个函数 g，用积分读取 $\langle g, e_k\rangle = \int_0^1 g\,e_k\,\mathrm{d}x$，(b) 中的读数趋于零，而 (a) 中函数本身的长度不变。逐个读数都收敛到零，整个函数却没有在范数下靠近零。

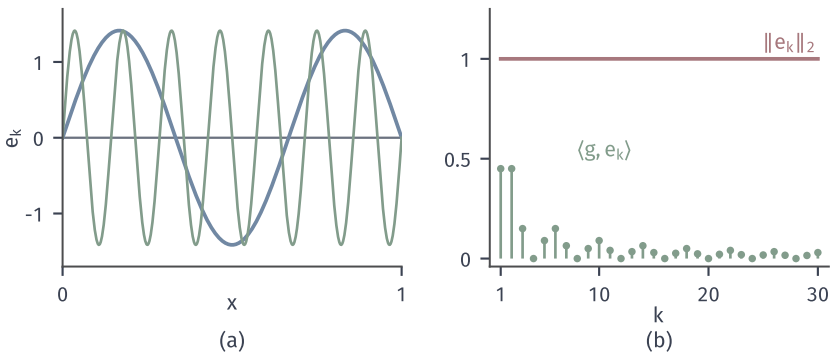


图 29.3 弱收敛而范数不收敛。(a)$e_k = \sqrt{2}\sin(k\pi x)$，蓝色 $k = 3$，绿色 $k = 14$。(b) 红线是 $\|e_k\|_2 = 1$，绿色竖线是用 $g = \mathbf{1}_{[0,1/2]}$ 读取的 $|\langle g, e_k\rangle|$，它随 k 趋于零。

这种“每个连续读取都收敛”的收敛称为弱收敛。设 X 是赋范空间，X^* 是它的对偶空间，即全体连续线性泛函。若对每个 $\xi \in X^*$ 都有 $\xi(u^{(k)}) \to \xi(u)$，就说 $u^{(k)}$ 弱收敛到 u，记作 $u^{(k)} \rightharpoonup u$。在 Hilbert 空间中，这就是对每个 g 都有 $\langle g, u^{(k)}\rangle \to \langle g, u\rangle$。

弱收敛正好补上第一关。我们使用两条结论。若 X 是反射空间，则每个有界序列都有弱收敛的子列；Hilbert 空间和 $1 < p < \infty$ 的 L^p 都是反射空间，L^1 不是。若 $u^{(k)} \rightharpoonup u$，则 $\|u\| \le \liminf_k \|u^{(k)}\|$，即弱极限的范数不会变大。证明可参考卷四第 16 章“线性泛函”，后面要用的 Riesz 表示定理也在同一章。上面的 e_k 弱收敛到 0，而 $\|0\|_2 = 0 < 1$，不等号可以严格成立。

代价是后两关要跟着变。极限现在是弱极限，所以要求可行集对弱极限封闭，要求目标对弱极限不向上跳。

定义 29.2 弱序列闭与弱序列下半连续 设 $\boldsymbol{C} \subseteq X$。若 $\boldsymbol{C}$ 中序列的每个弱极限仍在 $\boldsymbol{C}$ 中，称 $\boldsymbol{C}$**弱序列闭**（weakly sequentially closed）。设 $J : \boldsymbol{C} \to \mathbb{R} \cup \{+\infty\}$，若对 $\boldsymbol{C}$ 中每个弱收敛到 $u \in \boldsymbol{C}$ 的序列都有

$$J(u) \le \liminf_{k\to\infty} J(u^{(k)}), \tag{29.9}$$

称 J**弱序列下半连续**（weakly sequentially lower semicontinuous）。

弱收敛比范数收敛容易发生，要对所有弱收敛序列成立的性质就更难满足。弱序列闭蕴含闭，反过来不成立；弱序列下半连续蕴含下半连续，反过来也不成立。

存在定理 三关都有了新形式，图 29.4把它们排成一条链，并在下方列出有限维的对应要求。有限维中“有界”和“有收敛子列”由同一条性质负责，无限维中分成了两步：强制性给出有界，反射性给出弱子列。

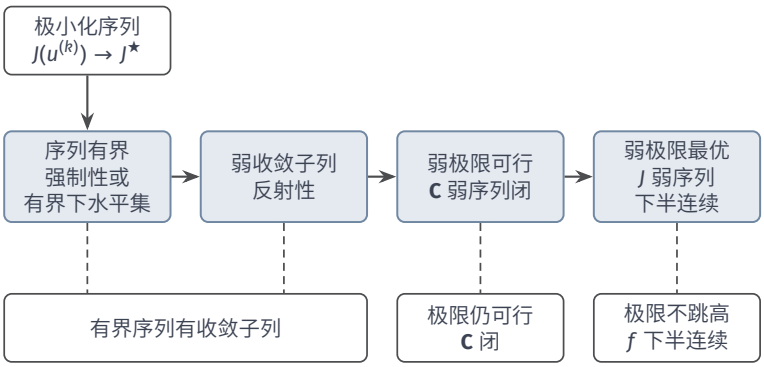


图 29.4 直接法的四步。上排蓝框是函数空间中的要求，每一步下方的白框是有限维的对应要求，有限维中有界序列必有收敛子列，所以前两步合成一个要求。

定理 29.3 直接法 设 X 是实反射 Banach 空间，$\boldsymbol{C} \subseteq X$ 非空且弱序列闭，$J : \boldsymbol{C} \to \mathbb{R} \cup \{+\infty\}$ 弱序列下半连续。若存在实数 a，使下水平集

$$\boldsymbol{S}_a = \{u \in \boldsymbol{C} : J(u) \le a\} \tag{29.10}$$

非空且有界，则 $J^\star$ 是有限实数，且问题 (29.4)有最优解。

证明 由 $\boldsymbol{S}_a$ 非空，有 $J^\star \le a$。若 $J^\star = a$，$\boldsymbol{S}_a$ 中的任一点已是最优解。下设 $J^\star < a$，取 $\boldsymbol{C}$ 中的序列 $u^{(k)}$，使 $J(u^{(k)})$ 递减到 $J^\star$，并使各项都不超过 a。这样的序列称为极小化序列，这里 $J^\star$ 暂时可能是 $-\infty$。

序列全在有界集 $\boldsymbol{S}_a$ 中。X 反射，所以有子列弱收敛到某个 $u^\star \in X$，子列仍记作 $u^{(k)}$。$\boldsymbol{C}$ 弱序列闭，所以 $u^\star \in \boldsymbol{C}$。由弱序列下半连续性，

$$J(u^\star) \le \liminf_{k\to\infty} J(u^{(k)}) = J^\star.$$

J 不取 $-\infty$，所以 $J^\star$ 有限。又因 $u^\star$ 可行，有 $J(u^\star) \ge J^\star$，两式合起来得到 $J(u^\star) = J^\star$。 ■

这种方法不写任何方程，直接对最小化序列取极限，称为**直接法**（direct method）。下水平集有界的最常见来源是强制性，即 $\|u\| \to \infty$ 时 $J(u) \to +\infty$。各条件的作用是：有界集把序列留住，反射性从中选出弱极限，弱序列闭保证弱极限合法，弱序列下半连续保证弱极限不比序列差。

怎样检查弱条件 定义里的条件要对所有弱收敛序列验证，直接检查很困难。凸性把它们化成了容易检查的范数条件。先看可行集。

引理 29.4　闭凸集弱序列闭　设 H 是 Hilbert 空间，$\boldsymbol{C} \subseteq H$ 是闭凸集。则 $\boldsymbol{C}$ 弱序列闭。

证明　设 $u^{(k)} \in \boldsymbol{C}$，$u^{(k)} \rightharpoonup u$。令 p 为 u 到 $\boldsymbol{C}$ 的最近点：到 $\boldsymbol{C}$ 的距离的极小化序列，由平行四边形恒等式和凸性是 Cauchy 列，它的极限就是 p。

任取 $c \in \boldsymbol{C}$，$t \in (0,1]$，点 $p + t(c-p)$ 在 $\boldsymbol{C}$ 中，所以它到 u 的距离不小于 $\|u-p\|_2$。展开平方，除以 t，再令 $t \to 0$，得到

$$\langle u - p,\, c - p \rangle \le 0.$$

取 $c = u^{(k)}$，让 $k \to \infty$。左端是固定向量 $u-p$ 对 $u^{(k)} - p$ 的读取，由弱收敛，得到

$$\|u-p\|^2 = \langle u-p,\, u-p\rangle \le 0.$$

所以 $u = p \in \boldsymbol{C}$。 ∎

几何上，证明说的是：若弱极限在 $\boldsymbol{C}$ 之外，就有一个超平面把它和 $\boldsymbol{C}$ 分开，而这个超平面对应的线性读取在弱收敛下是连续的，序列不可能跨过去。一般 Banach 空间中结论同样成立，称为 Mazur 定理，证明把最近点换成 Hahn–Banach 分离定理。

引理 29.5　凸与下半连续蕴含弱序列下半连续　设 $\boldsymbol{C}$ 是 Hilbert 空间中的闭凸集，$J : \boldsymbol{C} \to \mathbb{R} \cup \{+\infty\}$ 是凸函数，且在范数下下半连续。则 J 弱序列下半连续。

证明　对实数 a，由 J 凸知 $\boldsymbol{S}_a$ 是凸集，由下半连续和 $\boldsymbol{C}$ 闭知 $\boldsymbol{S}_a$ 是闭集，再由引理 29.4，$\boldsymbol{S}_a$ 弱序列闭。

设 $u^{(k)} \rightharpoonup u$，但 $\liminf_k J(u^{(k)}) < J(u)$。取实数 a 严格介于两者之间，则有子列落在 $\boldsymbol{S}_a$ 中。它的弱极限 u 也在 $\boldsymbol{S}_a$ 中，即 $J(u) \le a$，与 $a < J(u)$ 矛盾。 ∎

回到式 (29.3)。可行集 (29.7)是由两个连续线性条件给出的闭仿射集，是闭凸集；由式 (29.6)，端点读取在 H^1 中连续。$E = \tfrac{1}{2}\|u\|_{H^1}^2$ 是凸的连续函数，下水平集都有界。定理 29.3的条件全部满足，所以 E 的极小点存在。

积分目标的存在定理 下面的结论把上述检查做成一个可以直接使用的形式。它把密度分成导数部分和函数值部分，两部分起的作用不同。

定理 29.6 可分离密度的存在性 设 $G:\mathbb{R}\to\mathbb{R}$ 是凸的连续函数，并存在 $c>0$ 和 $d\ge 0$ 使 $G(p)\ge cp^2-d$。设 $V:[0,1]\times\mathbb{R}\to\mathbb{R}$ 连续且下有界。对给定的实数 α,β，在

$$\boldsymbol{C}=\{u\in H^1(0,1):u(0)=\alpha,\ u(1)=\beta\} \tag{29.11}$$

上，目标

$$J(u)=\int_0^1\Big(G\big(u'(x)\big)+V\big(x,u(x)\big)\Big)\,\mathrm{d}x \tag{29.12}$$

有极小点。

证明 有界下水平集。线性函数 u_0 过两个端点，$J(u_0)$ 有限；取 $a=J(u_0)$。设 $J(u)\le a$，$V\ge -d'$，由增长条件，

$$c\|u'\|_2^2\le a+d+d'.$$

$u-u_0\in H_0^1(0,1)$，由 Poincaré 不等式，$\|u-u_0\|_2\le\|u'-u_0'\|_2$。所以 $\boldsymbol{S}_a$ 在 H^1 中有界。

可行集。$\boldsymbol{C}$ 是闭仿射集，由引理 29.4，它弱序列闭。

弱序列下半连续。设 $u^{(k)}\rightharpoonup u$ 于 H^1，取子列使 $J(u^{(k)})$ 趋于下极限，不妨设下极限有限。弱收敛序列有界，再由连续代表的等式和 Cauchy–Schwarz 不等式，

$$|u^{(k)}(x)-u^{(k)}(y)|\le|x-y|^{1/2}\|u^{(k)\prime}\|_2.$$

所以 $u^{(k)}$ 一致有界且等度连续。由 Arzelà–Ascoli 定理，再取子列，它在 $[0,1]$ 上一致收敛，极限必为 u。V 在紧集上一致连续，于是

$$\int_0^1 V(x,u^{(k)})\,\mathrm{d}x\to\int_0^1 V(x,u)\,\mathrm{d}x.$$

对每个 $g\in L^2$，$v\mapsto\int_0^1 gv'\,\mathrm{d}x$ 是 H^1 上的连续线性泛函，所以 $u^{(k)\prime}\rightharpoonup u'$ 于 L^2。泛函 $w\mapsto\int_0^1 G(w)\,\mathrm{d}x$ 在 L^2 上是凸的。它也下半连续：范数收敛序列有几乎处处收敛的子列，$G+d\ge 0$，对其用 Fatou 引理即可。由引理 29.5，

$$\int_0^1 G(u')\,\mathrm{d}x\le\liminf_{k\to\infty}\int_0^1 G(u^{(k)\prime})\,\mathrm{d}x.$$

两部分相加即得式 (29.9)，再由定理 29.3得到结论。 ■

证明展示了分工。函数值 $u^{(k)}$ 因为一维的紧嵌入而一致收敛，所以 V 不需要任何凸性。导数 $u^{(k)\prime}$ 只有弱收敛，所以 G 必须对 p 是凸的。E 的 $G=\frac{1}{2}p^2$，$V=\frac{1}{2}s^2$，满足定理。

第一关失败：序列没有界，或者没有弱极限 下面逐条去掉条件。第一个例子去掉强制性。考虑区间 $[-1,1]$ 上的目标

$$J(u)=\int_{-1}^{1} x^2 u'(x)^2\,\mathrm{d}x, \qquad u(-1)=-1,\ u(1)=1.$$

权函数 x^2 在原点为零，那里的导数几乎不被惩罚。取图 29.5(a) 的折线 $u^{(k)}(x)=\max\{-1,\min\{1,kx\}\}$，导数只在 $|x|<1/k$ 上非零，等于 k。代入得到

$$J(u^{(k)})=\int_{-1/k}^{1/k} x^2 k^2\,\mathrm{d}x=\frac{2}{3k}\to 0.$$

所以 $J^\star=0$。若有 $u\in H^1(-1,1)$ 使 $J(u)=0$，则 $u'=0$ 几乎处处，u 是常数，这与两端的值 $-1,1$ 矛盾，极小点不存在。此时导数的长度 $\|u^{(k)\prime}\|_2^2=2k$ 趋于无穷，序列在 H^1 中无界，J 不强制。序列想要趋向的跳跃函数也不在 H^1 中。

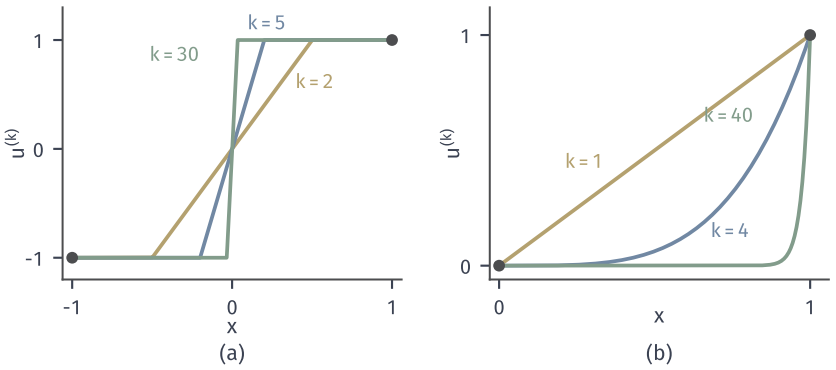


图 29.5 第一关的两种失败，灰点是固定端点。(a)$\int_{-1}^{1} x^2u'^2\,\mathrm{d}x$ 的极小化序列 $u^{(k)}=\max\{-1,\min\{1,kx\}\}$，目标值 $2/(3k)$ 趋于零，导数的长度趋于无穷。(b)$\int_0^1(|u'|+u^2)\,\mathrm{d}x$ 的极小化序列 $u^{(k)}=x^k$，$W^{1,1}$ 范数有界，所有质量向 $x=1$ 处的跳跃集中。

第二个例子去掉反射性。在 $W^{1,1}(0,1)$ 上取端点条件 $u(0)=0$、$u(1)=1$，目标

$$J(u)=\int_0^1 \big(|u'(x)|+u(x)^2\big)\,\mathrm{d}x.$$

曲线从 0 升到 1，导数绝对值的积分不小于总上升量：

$$\int_0^1 |u'|\,\mathrm{d}x \geq |u(1)-u(0)| = 1.$$

所以 $J \geq 1$。取图 29.5(b) 的 $u^{(k)} = x^k$，它单调上升，所以

$$J(u^{(k)}) = 1 + \frac{1}{2k+1} \to 1.$$

因此 $J^\star = 1$。若 $J(u) = 1$，则 $\int_0^1 u^2\,\mathrm{d}x = 0$，$u$ 恒为零，与 $u(1) = 1$ 矛盾，极小点不存在。这次序列有界，它的 $W^{1,1}$ 范数满足

$$\|u^{(k)}\|_1 + \|u^{(k)\prime}\|_1 \leq 2.$$

但它没有弱收敛子列。若有，弱极限几乎处处等于序列的逐点极限 0，而端点读取在 $W^{1,1}$ 中连续，弱极限在 $x = 1$ 处又应等于 1。把平方积分的 $|u'|^2$ 换成 $|u'|$，反射性就失去了，定理 29.6中 cp^2 的增长条件正是在防止这种情况。

第二关失败：弱极限不可行 闭集未必弱序列闭。取 $\boldsymbol{C}$ 为 $L^2(0,1)$ 中的单位球面，目标 $J(u) = \int_0^1 x\,u(x)^2\,\mathrm{d}x$。这相当于分配总量为 1 的质量，放在 x 处的代价是 x，质量当然想挤到原点。取 $u^{(k)} = \sqrt{k}\,\mathbf{1}_{[0,1/k]}$，见图 29.6，得到

$$\|u^{(k)}\|_2 = 1, \qquad J(u^{(k)}) = k\int_0^{1/k} x\,\mathrm{d}x = \frac{1}{2k} \to 0.$$

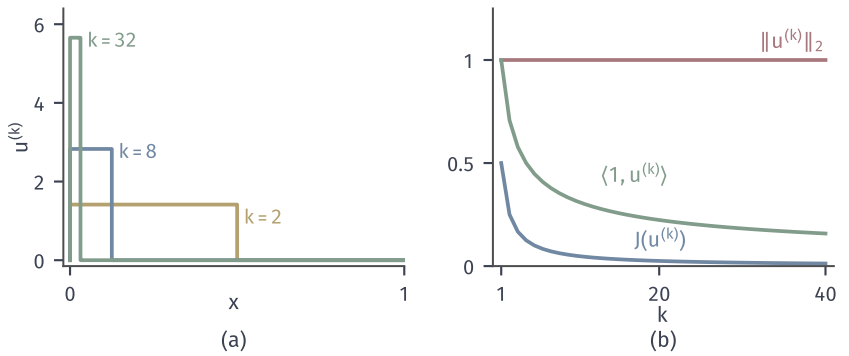


图 29.6 第二关的失败：单位球面不弱序列闭。(a)$u^{(k)} = \sqrt{k}\,\mathbf{1}_{[0,1/k]}$ 越来越高、越来越窄。(b) 红线是不变的长度，绿线是读取 $\langle 1, u^{(k)}\rangle = k^{-1/2}$，蓝线是目标值 $1/(2k)$。

$J(u) = 0$ 要求 $u = 0$ 几乎处处，但零函数不在球面上，所以极小点不存在。对任意 $g \in L^2$，由 Cauchy–Schwarz 不等式，

$$|\langle g, u^{(k)}\rangle| \leq \|g\|_{L^2(0,1/k)} \to 0.$$

所以 $u^{(k)} \rightharpoonup 0$。球面上的序列弱收敛到球心，弱极限离开了可行集。在有限维中球面是紧集，这个现象不会发生。把可行集放大成单位闭球，它是闭凸集，极小点 $u = 0$ 立即存在。

第三关失败：弱极限比序列差 最后去掉对导数的凸性。在 $H^1(0,1)$ 上考虑

$$J(u) = \int_0^1 \Big(\big(u'(x)^2 - 1\big)^2 + u(x)^2 \Big)\, \mathrm{d}x, \qquad u(0) = u(1) = 0, \tag{29.13}$$

其中 $u' \notin L^4$ 时 J 取 $+\infty$。第一项希望斜率是 ± 1，第二项希望 u 接近零。取图 29.7(a) 的锯齿 z_k：k 个相同的齿，斜率 ± 1，高度 $1/(2k)$。第一项为零，第二项每个齿贡献 $\frac{2}{3}(2k)^{-3}$，总计

$$J(z_k) = k \cdot \frac{2}{3} \cdot \frac{1}{8k^3} = \frac{1}{12k^2} \to 0.$$

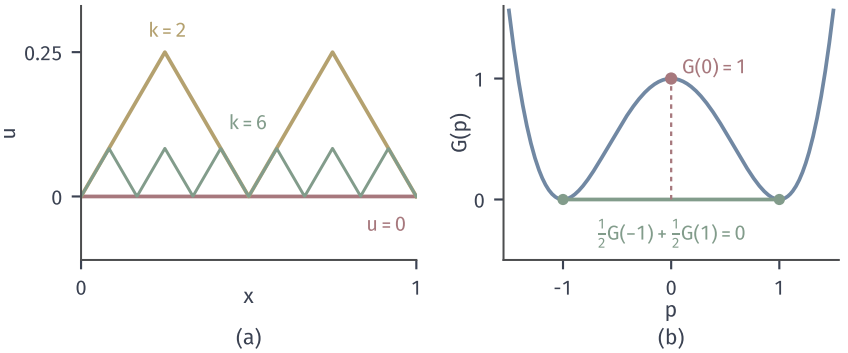


图 29.7 第三关的失败。(a) 目标 (29.13)的锯齿极小化序列，黄色 $k = 2$，绿色 $k = 6$，红线是弱极限 $u = 0$。(b) 导数部分的密度 $G(p) = (p^2 - 1)^2$：斜率 ± 1 各占一半时，平均代价是绿线上的 0，而平均斜率 0 自身的代价是红点 1。

所以 $J^\star = 0$。$J(u) = 0$ 要求 $u = 0$，同时要求 $|u'| = 1$ 几乎处处，二者矛盾，极小点不存在。序列在 H^1 中有界，并且 $z_k \rightharpoonup 0$，弱极限 0 是可行的，但 $J(0) = 1$。弱极限比序列差了整整一个单位，式 (29.9)不成立。

机制在图 29.7(b)。弱收敛只记住了斜率的局部平均，而锯齿的平均斜率是 0。G 在 ± 1 处为零，而在两者的平均 0 处等于 1，这就是 G 非凸。若 G 是凸的，Jensen 不等式给出“平均的代价不超过代价的平均”，弱极限就不会变差。

29.1 泛函优化问题
29.2 极小值的存在
29.3 泛函的微分
29.3.1 方向微分与线性近似
29.3.2 Hilbert 梯度
29.4 最优解的判别
29.5 积分泛函
29.6 有限维近似
29.7 本章小结

驻定不能代替存在 还有一种常见的想法：写出令导数为零的方程，解出来就是答案。下面的例子说明，这样做既不能证明解存在，得到的候选也未必是解。在 $\boldsymbol{V} = H_0^1(0,1)$ 上取实数 ρ，考虑

$$J_\rho(u) = \int_0^1 \Big(\frac{1}{2} u'(x)^2 - \frac{\rho}{2} u(x)^2 \Big) \,\mathrm{d}x. \tag{29.14}$$

沿任何一条过原点的直线都有 $J_\rho(t\eta) = t^2 J_\rho(\eta)$，这是 t 的一元二次函数，在 $t = 0$ 处导数为零。所以 $u = 0$ 沿每个方向都是平的，它满足任何合理的驻定条件。

取方向 $\eta(x) = \sin \pi x$。由 $\int_0^1 \eta'^2 \,\mathrm{d}x = \pi^2/2$，$\int_0^1 \eta^2 \,\mathrm{d}x = 1/2$，得到

$$J_\rho(t \sin \pi x) = \frac{t^2}{4}(\pi^2 - \rho).$$

图 29.8画了三种情形。$\rho > \pi^2$ 时，沿这个方向目标趋于 $-\infty$，$J_\rho^\star = -\infty$，极小点不存在，而 $u = 0$ 仍然驻定。

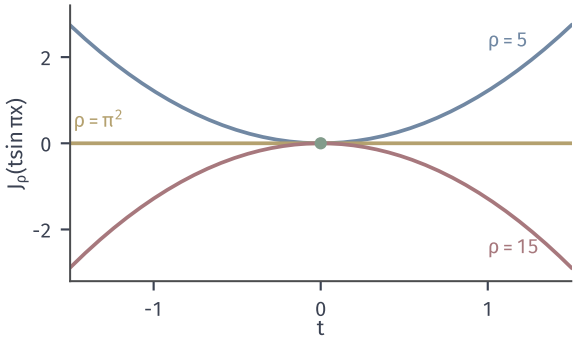


图 29.8 目标 (29.14)沿 $t \sin \pi x$ 的取值。绿点 $t = 0$ 在三种情形下都驻定。$\rho = 5$ 时是开口向上的抛物线，$\rho = \pi^2$ 时恒为零，$\rho = 15$ 时向下，目标无下界。

这个 J_ρ 对每个 ρ 都弱序列下半连续：$\int u'^2$ 部分是凸的，$\int u^2$ 部分在弱收敛下连续。失败的只是下水平集的有界性。“若极小点存在，则它满足驻定方程”是一个条件命题，它的前提要靠本节的论证另行建立。

29.3 泛函的微分

有限维中，一点处的梯度告诉我们目标沿每个方向的一阶变化。这就需要回答：对泛函，同样的事情怎样表述？方向上的变化率总可以先算，它能否合成一个线性近似，线性近似又能否写成一个梯度，这是三个不同的问题。

29.1 泛函优化问题
29.2 极小值的存在
29.3 泛函的微分
29.3.1 方向微分与线性近似
29.3.2 Hilbert 梯度
29.4 最优解的判别
29.5 积分泛函
29.6 有限维近似
29.7 本章小结

29.3.1 方向微分与线性近似

沿一条直线看 给定候选 u 和扰动 η，让实数 t 控制扰动的大小。整条曲线沿“方向”η 移动，目标变成一元函数

$$\phi(t) = J(u + t\eta). \tag{29.15}$$

这是最重要的一步化归：一元函数我们已经会求导。

下面用式 (29.3)的 E 计算一次。取 $u(x) = x$，$\eta(x) = x(1-x)$，它们满足 $\eta(0) = \eta(1) = 0$，所以 $x+t\eta$ 对每个 t 都可行。导数是 $(x+t\eta)' = 1+t(1-2x)$，代入后按 t 的幂次展开，需要三个积分：

$$\int_0^1 (1-2x)\,\mathrm{d}x = 0, \qquad \int_0^1 (1-2x)^2\,\mathrm{d}x = \frac{1}{3}, \qquad \int_0^1 x\cdot x(1-x)\,\mathrm{d}x = \frac{1}{12}.$$

再加上 $\int_0^1 x^2(1-x)^2\,\mathrm{d}x = \frac{1}{30}$ 和 $E(x) = \frac{2}{3}$，得到

$$\phi(t) = \frac{2}{3} + \frac{t}{12} + \frac{11}{60}t^2. \tag{29.16}$$

所以 $\phi'(0) = 1/12$。图 29.9的 (a) 是这一族曲线，(b) 是 ϕ 及其切线。注意这里求导的变量是 t，不是 x：$u'(x)$ 描述一条固定曲线的陡峭程度，$\phi'(0)$ 描述整条曲线改动时目标的响应。

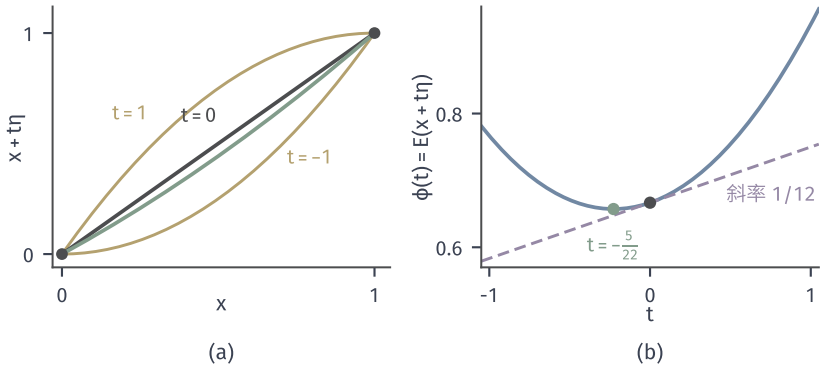


图 29.9 沿一个方向改动整条曲线。(a)$u = x$（深灰）和 $\eta = x(1-x)$ 给出的曲线族 $x + t\eta$，黄色 $t = \pm 1$，绿色 $t = -5/22$，端点不动。(b)$\phi(t) = E(x + t\eta)$，紫色虚线是 $t = 0$ 处的切线，斜率 $1/12$；绿点是这条直线上的最小点 $t = -5/22$。

ϕ 在 $t = -5/22$ 处最小，说明沿这个方向还能下降，x 不是极小点。这个判断只用了一元微积分。

定义 29.7 方向导数 设 X 是实赋范空间，$J(u)$ 有限，$\eta \in X$，且 $t>0$ 充分小时 $J(u+t\eta)$ 有限。若极限

$$J'(u;\eta)=\lim_{t\downarrow 0}\frac{J(u+t\eta)-J(u)}{t} \tag{29.17}$$

存在且有限，称它为 J 在 u 处沿 η 的**方向导数**（directional derivative）。

定义只取 $t\downarrow 0$ 的单侧极限，因为有约束时常常只能朝一侧走。方向导数只回答一条直线上的问题，把所有方向的答案放在一起，未必是线性函数。在 $L^2(0,1)$ 上取 $J(u)=\int_0^1 |u|\,\mathrm{d}x$，由齐次性直接得到 $J'(0;\eta)=\int_0^1|\eta|\,\mathrm{d}x$。它对 η 不可加，$J'(0;\eta)+J'(0;-\eta)$ 也不为零。这与 $|x|$ 在原点的尖角相同。

线性且连续：Gâteaux 微分 有限维中，光滑函数的方向导数是 $\nabla f(\boldsymbol{x})^{\top}\boldsymbol{d}$，对 $\boldsymbol{d}$ 线性。线性是我们想要的结构，无限维中还要多要求一件事：连续。有限维的线性函数自动连续，无限维的线性泛函不然。

定义 29.8 Gâteaux 微分 若 $J'(u;\eta)$ 对每个 $\eta\in X$ 存在，且 $\eta\mapsto J'(u;\eta)$ 是 X 上的连续线性泛函，称 J 在 u 处Gâteaux **可微**（Gâteaux differentiable），称这个泛函为 J 在 u 处的Gâteaux **微分**（Gâteaux derivative），记作 $DJ(u)\in X^{*}$，即

$$DJ(u)[\eta]=J'(u;\eta). \tag{29.18}$$

线性中已经包含 $J'(u;-\eta)=-J'(u;\eta)$，所以这时 $t\to 0$ 的双侧极限也存在。Gâteaux 微分还是逐方向定义的：对每个固定的 η，t 足够小时余项才小，“足够小”的程度可以随方向变化。

一致的余项：Fréchet 微分 真正的线性近似要求：只要扰动在范数下小，余项就比范数小，不管扰动沿哪个方向。

定义 29.9 Fréchet 微分 设 J 在 u 的某邻域内有限。若存在 $\xi\in X^{*}$ 使

$$\lim_{\|\eta\|\to 0}\frac{|J(u+\eta)-J(u)-\xi(\eta)|}{\|\eta\|}=0, \tag{29.19}$$

称 J 在 u 处Fréchet **可微**（Fréchet differentiable），ξ 称为 Fréchet 微分。

两个定义的差别只在极限的取法。Gâteaux 微分固定形状，只缩小幅度；Fréchet 微分允许形状和幅度同时变化。无限维中形状可以无穷多，这个差别才变得实质。

一个 Gâteaux 可微而非 Fréchet 可微的泛函 下面的例子说明，这个差别由范数决定。考虑

$$S(u) = \int_0^1 \sin\big(u(x)\big)\,\mathrm{d}x. \tag{29.20}$$

先在 $X = L^1(0,1)$ 的 $u = 0$ 处计算方向导数。差商的被积函数 $\sin(t\eta)/t$ 逐点趋于 η，并被可积函数 $|\eta|$ 控制，由控制收敛定理，

$$S'(0;\eta) = \int_0^1 \eta(x)\,\mathrm{d}x.$$

它线性，并且不超过 $\|\eta\|_1$，所以 S 在 0 处 Gâteaux 可微。

再测试余项。取图 29.10(a) 的尖峰 $\eta_k = \pi \mathbf{1}_{[0,1/k]}$，幅度始终是 π，宽度趋于零。余项为

$$S(\eta_k) - S(0) - \int_0^1 \eta_k\,\mathrm{d}x = \frac{1}{k}\big(\sin\pi - \pi\big) = -\frac{\pi}{k}.$$

而 $\|\eta_k\|_1 = \pi/k$，比值的绝对值恒等于 1，不趋于零。所以 S 在 L^1 中不是 Fréchet 可微的。

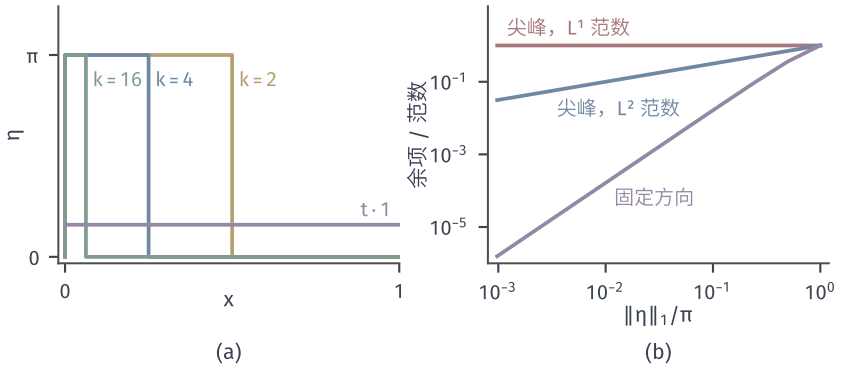


图 29.10 同一泛函 $S(u) = \int_0^1 \sin u\,\mathrm{d}x$ 在 $u = 0$ 处的余项。(a) 尖峰扰动 $\pi\mathbf{1}_{[0,1/k]}$（$k = 2, 4, 16$）与固定方向的缩小 $t \cdot 1$（紫色）。(b) 余项除以范数：尖峰在 L^1 范数下恒为 1（红），在 L^2 范数下按 $k^{-1/2}$ 衰减（蓝）；固定方向 $t \cdot 1$ 按 t^2 衰减（紫）。

换成 $X = L^2(0,1)$，同一个尖峰的范数是 $\|\eta_k\|_2 = \pi k^{-1/2}$，比 L^1 范数大得多，比值变成 $k^{-1/2} \to 0$。这不是巧合。由 Taylor 公式，逐点有

$$|\sin(u+\eta) - \sin u - \eta\cos u| \le \frac{1}{2}\eta^2.$$

两边积分，得到

$$\Big|S(u+\eta) - S(u) - \int_0^1 \eta\cos u\,\mathrm{d}x\Big| \le \frac{1}{2}\|\eta\|_2^2.$$

所以 S 在 L^2 中处处 Fréchet 可微。在 L^1 中，窄而高的尖峰范数很小，函数值的改动却不小；L^2 范数对尖峰更敏感，把它们排除在“小扰动”之外。讨论可微性时必须说清范数。

两种微分的关系　下面的定理说明，Fréchet 可微更强，以及在什么条件下两者相同。

定理 29.10　Gâteaux 与 Fréchet　设 J 在 u 的某邻域内有限。

1. 若 J 在 u 处 Fréchet 可微，则 J 在 u 处 Gâteaux 可微，且 $DJ(u)=\xi$。
2. 若 J 在 u 的邻域内 Gâteaux 可微，且映射 $v\mapsto DJ(v)$ 在 u 处从 X 到 X^{*} 连续，则 J 在 u 处 Fréchet 可微。

证明　(1) 固定 $\eta\neq 0$，在式 (29.19)中用 $t\eta$ 代替 η，$t\downarrow 0$ 时 $\|t\eta\|\to 0$。两边除以 t，得到差商趋于 $\xi(\eta)$。

(2) 取 $\|\eta\|$ 足够小，使线段 $u+t\eta$（$t\in[0,1]$）落在邻域内。$\phi(t)=J(u+t\eta)$ 在 $[0,1]$ 上可导，$\phi'(t)=DJ(u+t\eta)[\eta]$。由 Lagrange 中值定理，存在 $\theta\in(0,1)$，使

$$J(u+\eta)-J(u)=DJ(u+\theta\eta)[\eta].$$

两边减去 $DJ(u)[\eta]$，再用对偶范数的定义，得到

$$\bigl|J(u+\eta)-J(u)-DJ(u)[\eta]\bigr|\le \|DJ(u+\theta\eta)-DJ(u)\|\,\|\eta\|.$$

由连续性，$\|\eta\|\to 0$ 时右端的第一个因子趋于零。 ∎

这解释了 S 在 L^1 中的情形：$DS(v)$ 是乘以 $\cos v$ 的积分，L^1 范数很小的尖峰可以让 $\cos v$ 在一小段上改变一个固定的量，所以微分在 $X^{*}=L^{\infty}$ 中不连续，第二条的条件不满足。

三个层次可以列表比较。

表 29.2　一阶信息的三个层次。

层次	要求	不满足下一层的例子
方向导数	每条直线上有导数	$\int_0^1 \lvert u\rvert\,\mathrm{d}x$ 在 $u=0$
Gâteaux 微分	上述导数线性连续	$\int_0^1 \sin u\,\mathrm{d}x$ 在 L^1
Fréchet 微分	余项对方向一致	—

29.1 泛函优化问题
29.2 极小值的存在
29.3 泛函的微分
29.3.1 方向微分与线性近似
29.3.2 Hilbert 梯度
29.4 最优解的判别
29.5 积分泛函
29.6 有限维近似
29.7 本章小结

能量的展开 回到 E。对 $u,\eta\in H^1(0,1)$，把平方展开，不做任何近似：

$$E(u+\eta)=E(u)+\int_0^1\left(u'\eta'+u\eta\right)\mathrm{d}x+\frac{1}{2}\|\eta\|_{H^1}^2. \tag{29.21}$$

中间一项是 η 的线性泛函。由 Cauchy–Schwarz 不等式，它的绝对值不超过 $\|u\|_{H^1}\|\eta\|_{H^1}$，所以连续。余项是 $\frac{1}{2}\|\eta\|_{H^1}^2$，比 $\|\eta\|_{H^1}$ 高一阶。因此 E 在 H^1 中处处 Fréchet 可微，

$$DE(u)[\eta]=\int_0^1\left(u'\eta'+u\eta\right)\mathrm{d}x. \tag{29.22}$$

取 $u=x$，$\eta=x(1-x)$，右端是 $\int_0^1(1-2x)\,\mathrm{d}x+\frac{1}{12}=\frac{1}{12}$，与式 (29.16)一致。长度目标也可以同样处理：$G(p)=\sqrt{1+p^2}$ 满足 $0<G''\le 1$，由 Taylor 公式，余项不超过 $\frac{1}{2}\|\eta'\|_2^2$，所以 ℓ 在 H^1 中 Fréchet 可微。

29.3.2 Hilbert 梯度

微分 $DJ(u)$ 是一个把方向读成数的线性泛函，它是“行向量”。梯度下降需要的却是一个能和候选相加的“列向量”。本小节要回答的问题是：怎样把微分转成梯度？答案取决于内积。

有限维中内积就已经起作用 把向量和方向配对的是微分 $Df(\boldsymbol{x})[\boldsymbol{d}]=\nabla f(\boldsymbol{x})^{\top}\boldsymbol{d}$，这里的 ∇f 其实默认了欧氏内积。换一个内积，由对称正定矩阵 $\boldsymbol{M}$ 给出：

$$\langle \boldsymbol{x},\boldsymbol{y}\rangle_{\boldsymbol{M}}=\boldsymbol{x}^{\top}\boldsymbol{M}\boldsymbol{y}.$$

这时梯度应当是满足下式的向量 $\boldsymbol{g}$，内积下读出的就是同一个微分：

$$\boldsymbol{g}^{\top}\boldsymbol{M}\boldsymbol{d}=\nabla f(\boldsymbol{x})^{\top}\boldsymbol{d}\qquad\text{对每个 }\boldsymbol{d}.$$

解出来就是

$$\boldsymbol{g}=\boldsymbol{M}^{-1}\nabla f(\boldsymbol{x}). \tag{29.23}$$

用第 5章的例子 $f(\boldsymbol{x})=\frac{1}{2}(x_1^2+9x_2^2)$ 看，在 $\boldsymbol{x}=(9,1)$ 处，$\nabla f=(9,9)$。取 $\boldsymbol{M}=\mathrm{diag}(1,9)$，它是这个目标的 Hessian，代入式 (29.23)，

$$\boldsymbol{g}=(9,1).$$

图 29.11中，黄色箭头是欧氏梯度方向的一步，绿色箭头沿 $-\boldsymbol{g}$，一步直达原点。同一个微分，在两个内积下给出两个不同的梯度。“最速下降方向”依赖怎样度量步长的长度。

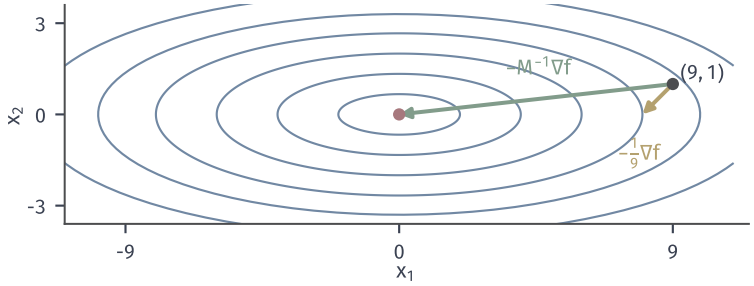


图 29.11　同一个微分在两个内积下的梯度。蓝色为 $f=\frac{1}{2}(x_1^2+9x_2^2)$ 的等高线，出发点 $(9,1)$。黄色箭头是步长 $1/9$ 的欧氏负梯度步，绿色箭头是 $\boldsymbol{M}=\mathrm{diag}(1,9)$ 内积下步长 1 的负梯度步，终点是最优解（红点）。

函数空间中的梯度　有限维中 $\boldsymbol{M}$ 可逆，这个转换永远可以做。在 Hilbert 空间中，转换由 Riesz 表示定理完成：H 上的每个连续线性泛函 ξ，都存在唯一的 $w\in H$，使 $\xi(\eta)=\langle w,\eta\rangle_H$ 对所有 $\eta\in H$ 成立。

定义 29.11　Hilbert 梯度　设 H 是实 Hilbert 空间，J 在 u 处沿 H 的方向 Gâteaux 可微。称满足

$$DJ(u)[\eta]=\big\langle \nabla_H J(u),\eta\big\rangle_H \qquad (\eta\in H) \tag{29.24}$$

的唯一元素 $\nabla_H J(u)\in H$ 为 J 在 u 处的Hilbert 梯度 (Hilbert gradient)。

由 Cauchy–Schwarz 不等式，在 $\|\eta\|_H=1$ 的方向中，$DJ(u)[\eta]$ 在 η 平行于 $\nabla_H J(u)$ 时最大，所以它确实是“上升最快的方向”，只是这里的“单位长度”用 H 的范数计量。

同一个微分的三个梯度　下面算一个具体例子。对 E 在 $u=x$ 处，方向取 $\boldsymbol{V}=H_0^1(0,1)$。由式 (29.22)和 $\int_0^1 \eta'\,\mathrm{d}x=\eta(1)-\eta(0)=0$，得到

$$DE(x)[\eta]=\int_0^1 x\,\eta(x)\,\mathrm{d}x. \tag{29.25}$$

这一个线性泛函，用三种内积表示。

第一种是 L^2 内积。式 (29.25)已经写成了 $\langle x,\eta\rangle_2$，所以 L^2 梯度是

$$w_1(x)=x.$$

第二种内积只用导数：

$$\langle v,\eta\rangle_{\boldsymbol{V}} = \int_0^1 v'\eta'\,\mathrm{d}x.$$

由 Poincaré 不等式它是 $\boldsymbol{V}$ 上的内积，$\boldsymbol{V}$ 在其下完备。要找 $w_2\in\boldsymbol{V}$，使它在这个内积下读出式 (29.25)。分部积分，边界项因 η 在端点为零而消失，问题化成 $-w_2''=x$，$w_2(0)=w_2(1)=0$。解得

$$w_2(x)=\frac{x-x^3}{6}.$$

第三种是 H^1 内积 $\int_0^1(v'\eta'+v\eta)\,\mathrm{d}x$。同样分部积分，问题化成 $-w_3''+w_3=x$，$w_3(0)=w_3(1)=0$。解得

$$w_3(x)=x-\frac{\sinh x}{\sinh 1}.$$

三个函数画在图 29.12中，形状和大小都不同，但它们表示同一个微分。用 $\eta=x(1-x)$ 检验，三种内积给出的都是 $1/12$。例如第二种：

$$\int_0^1 \frac{1-3x^2}{6}(1-2x)\,\mathrm{d}x=\frac{1}{12}.$$

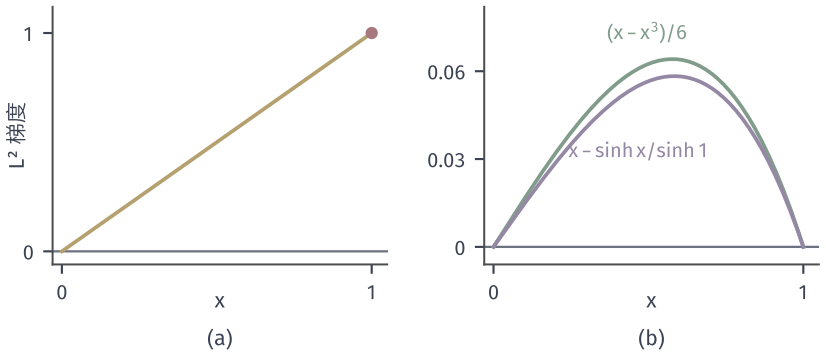


图 29.12　E 在 $u=x$ 处同一微分的三个梯度。(a)L^2 梯度 $w_1=x$，在 $x=1$ 处不为零（红点），不是允许的扰动方向。(b) 绿色 w_2 对应内积 $\int v'\eta'$，紫色 w_3 对应 H^1 内积，二者都在端点为零。注意两幅图的纵轴尺度相差十倍以上。

它们的差别有实际后果。w_1 在 $x=1$ 处等于 1，沿它走一步会破坏端点条件，它不是 $\boldsymbol{V}$ 中的元素：$\boldsymbol{V}$ 在 L^2 内积下不完备，Riesz 定理在这里并没有保证梯度落在 $\boldsymbol{V}$ 内。w_2,w_3 是 $\boldsymbol{V}$ 中的元素，沿它们走仍然可行。

w_3 还有一个特别之处。E 的二次项正是 H^1 内积，这和上面的 $\boldsymbol{M}$ 取 Hessian 相同，所以 $u-w_3=\sinh x/\sinh 1$ 一步到位。这条曲线就是图 29.2中绿色的候选，它的能量约为 0.6565，比 $E(x)=2/3$ 低；第 29.5节将确认它就是极小点。

函数梯度与坐标梯度 把函数离散成结点向量，函数的梯度与向量的梯度是什么关系？看最简单的 $J(u)=\frac{1}{2}\int_0^1 u^2\,\mathrm{d}x$，它的 L^2 梯度是 u。离散成 $J_n(\boldsymbol{u})=\frac{\Delta}{2}\sum_i u_i^2$，向量梯度的分量是 Δu_i，随网格加密趋于零。

要得到函数的梯度，必须除以 Δ。这正是式 (29.23)中取 $\boldsymbol{M}=\Delta\boldsymbol{I}$，也就是离散 L^2 内积 $\Delta\sum_i u_i v_i$。向量梯度依赖离散的细节，函数梯度依赖选定的内积，从前者到后者要乘以内积矩阵的逆。

梯度可以不存在 有限维中，每个线性函数都连续，所以任何内积下都有梯度。无限维不是这样。考虑 $E_0(u)=\frac{1}{2}\int_0^1 u'^2\,\mathrm{d}x$，在 $\boldsymbol{V}=H_0^1(0,1)$ 的帐篷函数 $u=\min\{x,1-x\}$ 处，把积分在 $x=\frac{1}{2}$ 处分开：

$$DE_0(u)[\eta]=\int_0^{1/2}\eta'\,\mathrm{d}x-\int_{1/2}^1\eta'\,\mathrm{d}x=2\,\eta\big(\tfrac{1}{2}\big).$$

微分只读取中点的值。在内积 $\int v'\eta'$ 下，由定义，$\nabla E_0(u)=u$，这是图 29.13(a) 的帐篷。

在 L^2 内积下，$\eta\mapsto 2\eta(\frac{1}{2})$ 不连续。取中点处高度为 1、半宽为 $1/k$ 的小帐篷 η_k，有

$$DE_0(u)[\eta_k]=2,\qquad \|\eta_k\|_2^2=\frac{2}{3k}\to 0.$$

没有 L^2 函数能表示这个读取，L^2 梯度不存在。形式上的“梯度”$-u''$ 是中点处质量为 2 的点质量，它不是函数。

把问题离散，就能看到这一点。线性元的结点向量梯度只在中点非零，等于 2；转成离散 L^2 梯度要除以 $\Delta=1/n$，于是高度为 $2n$。图 29.13(b) 的尖峰随网格加密无限增高，没有极限函数。

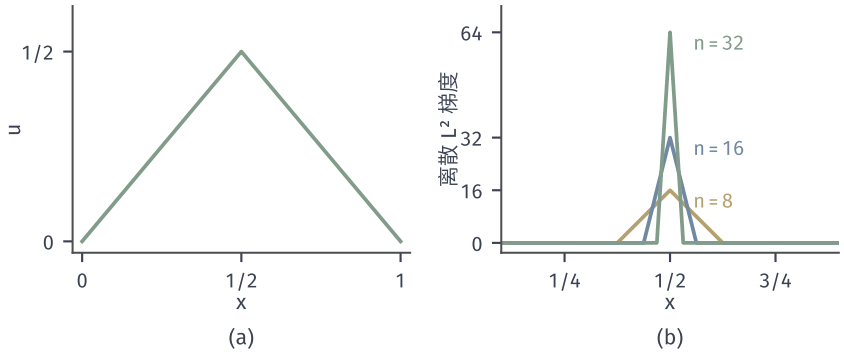


图 29.13 帐篷函数 $u=\min\{x,1-x\}$ 在 $E_0=\frac{1}{2}\int u'^2\,\mathrm{d}x$ 下的梯度。(a) 在内积 $\int v'\eta'$ 下，梯度就是 u 本身。(b) 离散 L^2 梯度，在 $n=8,16,32$ 段网格上中点高度为 $2n$，网格越细越高，没有极限函数。

选错内积的代价 即使 L^2 梯度存在，用它做下降也有问题。对式 (29.3)用 n 段线性元离散，在两种内积下跑步长为 $1/L$ 的梯度下降，L 是对应内积下的光滑常数。

L^2 内积下，L 约等于离散二阶差分的最大特征值 $4n^2$。$n = 16, 32, 64$ 时步长分别约为 9.9×10^{-4}、2.4×10^{-4}、6.1×10^{-5}，网格每加密一倍，步长缩小到四分之一。原因是 $-u''$ 是无界的运算，函数摆动越快，它放大得越多。

内积 $\int v'\eta'$ 下，相应的算子把频率 k 的分量放大 $1+(k\pi)^{-2}$ 倍，$L\approx1.10$ 与网格无关。图 29.14显示了结果，绿线几步就到达机器精度，黄线 100 步后目标差仍在 10^{-3} 到 10^{-2} 之间，而且网格越细越慢。

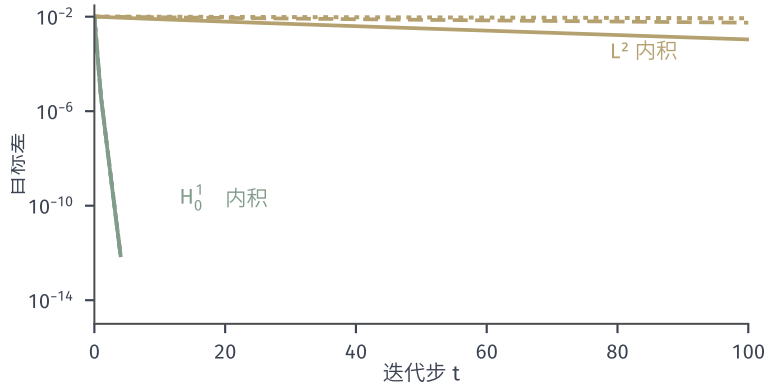


图 29.14 线性元离散的 E 上，步长 $1/L$ 的梯度下降从 $u = x$ 出发的目标差。黄色为 L^2 内积，绿色为内积 $\int v'\eta'$；实线、虚线、点线分别是 $n = 16, 32, 64$。绿色三条线重合，收敛不随网格变慢。

这和第 7章讲的二阶信息是同一件事：选一个接近 Hessian 的内积，就是做预条件。函数空间的视角补充的是：网格加密时，好的内积让迭代次数保持不变，这件事在单个有限维问题里看不出来。

类比到哪里为止 下面把向量与函数的对应关系补完，并列出类比失效的地方。

表 29.3 一阶信息的对应与差别。

	有限维	函数空间
闭球	紧	不紧，只有弱序列紧
范数	彼此等价	不等价，决定可微性
线性泛函	自动连续	可以不连续
梯度	任何内积下都存在	可能不存在
Hessian	有界	在 L^2 中可以无界

29.1 泛函优化问题
29.2 极小值的存在
29.3 泛函的微分
29.4 最优解的判别
29.5 积分泛函
29.6 有限维近似
29.7 本章小结

可以这样记：有限维的直觉在选定空间之后才能使用，选空间这一步是函数问题特有的。

29.4 最优解的判别

有了微分，就可以判别候选。泛函优化的最优解满足什么条件，什么条件又足以断定最优？一阶条件、凸性下的充分性与有限维完全平行；二阶充分性和约束乘子则要额外的前提。

局部极小依赖范数 在讲条件之前要先说清“局部”。设 J 定义在 $\boldsymbol{C}$ 上，若存在 $r>0$，使 $\|u-u^\star\|<r$ 的可行 u 都满足 $J(u)\ge J(u^\star)$，称 $u^\star$ 是范数 $\|\cdot\|$ 下的**局部极小点**（local minimizer）。有限维中范数等价，不用说明是哪一个；函数空间中必须说明。

看下面的例子。在 $[0,1]$ 上的 Lipschitz 函数中，取 $u(0)=u(1)=0$，目标

$$J(u)=\int_0^1 \big(u'(x)^2-u'(x)^4\big)\,\mathrm{d}x. \tag{29.26}$$

若用范数 $\|u\|_\infty+\|u'\|_\infty$，当它小于 1 时 $|u'|<1$，被积函数非负，$J\ge 0=J(0)$，所以 $u=0$ 是局部极小点。

若只用上确界范数 $\|u\|_\infty$，取图 29.15(a) 的锯齿：k 个相同的齿，斜率 ± 2。它的高度是 $1/k$，k 越大越贴近零函数；而被积函数处处等于 $4-16=-12$，

$$\|u\|_\infty=\frac{1}{k},\qquad J(u)=-12.$$

所以 $u=0$ 在上确界范数下不是局部极小点。前一种范数把导数也算进“接近”，这样的扰动被排除了。

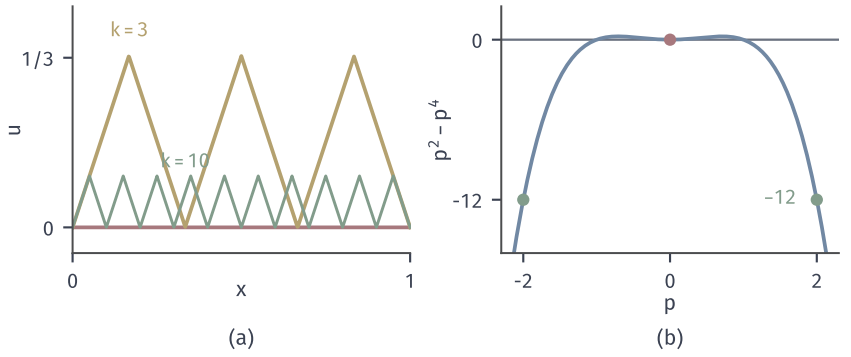


图 29.15 局部极小依赖范数。(a) 红线 $u=0$ 附近的锯齿，斜率 ± 2，黄色 $k=3$，绿色 $k=10$；上确界距离 $1/k$ 趋于零，而导数始终等于 ± 2。(b) 被积函数 p^2-p^4：$p=0$ 是局部极小（红点），大斜率处（绿点）取值 -12。

一阶必要条件 第 17章用可行方向得到一阶条件，这里的推理逐字相同，因为它只看一条线段。称 η 是 $\boldsymbol{C}$ 在 u 处的**可行方向**（feasible direction），若 $t>0$ 充分小时 $u+t\eta\in\boldsymbol{C}$。

定理 29.12 一阶必要条件 设 $u^\star$ 是 J 在 $\boldsymbol{C}$ 上某范数下的局部极小点，η 是 $u^\star$ 处的可行方向，方向导数存在。则

$$J'(u^\star;\eta)\geq 0. \tag{29.27}$$

进一步，设 J 在 $u^\star$ 处沿所需方向 Gâteaux 可微。若 $\boldsymbol{C}=u_0+\boldsymbol{V}$，$\boldsymbol{V}$ 是子空间，则

$$DJ(u^\star)[\eta]=0 \qquad (\eta\in\boldsymbol{V}). \tag{29.28}$$

若 $\boldsymbol{C}$ 是凸集，则

$$DJ(u^\star)[v-u^\star]\geq 0 \qquad (v\in\boldsymbol{C}). \tag{29.29}$$

证明 $t>0$ 充分小时，$u^\star+t\eta$ 可行，且与 $u^\star$ 的距离 $t\|\eta\|$ 小于 r，所以

$$\frac{J(u^\star+t\eta)-J(u^\star)}{t}\geq 0.$$

令 $t\downarrow 0$ 得到式 (29.27)。子空间情形中 η 和 $-\eta$ 都是可行方向，由线性得到两个相反的不等式，于是式 (29.28)成立。凸集情形中 $v-u^\star$ 是可行方向，代入式 (29.27)。 ■

式 (29.28)称为驻定条件，满足它的点称为驻点。若 $\boldsymbol{V}$ 上有 Hilbert 结构，它就是 $\nabla_{\boldsymbol{V}}J(u^\star)=0$。注意这里的梯度是 $\boldsymbol{V}$ 内的，X 内的梯度只需与 $\boldsymbol{V}$ 正交，这和等式约束问题中梯度落在约束法方向上相同。式 (29.29)是第 17章的变分不等式。

凸性下的充分性 凸性让局部信息变成全局结论。若 J 是凸泛函，沿线段的一元函数 ϕ 是凸的，切线在下方，由此得到下面的结论。

定理 29.13 凸问题的充分条件 设 $\boldsymbol{C}$ 是凸集，J 在 $\boldsymbol{C}$ 上是凸的，在 $u^\star\in\boldsymbol{C}$ 处有 $J'(u^\star;v-u^\star)\geq 0$，对每个 $v\in\boldsymbol{C}$ 成立。则 $u^\star$ 是全局最优解。若 J 严格凸，它是唯一的最优解。

证明 任取 $v \in \boldsymbol{C}$，令 $\phi(t) = J(u^\star + t(v-u^\star))$，$t \in [0,1]$。由凸性，$t \in (0,1]$ 时

$$\frac{\phi(t)-\phi(0)}{t} \le \phi(1)-\phi(0).$$

令 $t \downarrow 0$，左端趋于 $J'(u^\star; v-u^\star) \ge 0$，所以 $J(v) \ge J(u^\star)$。

若 J 严格凸，并有另一最优解 $v \neq u^\star$，则中点的目标值严格小于 $J^\star$，矛盾。 ■

对 E，式 (29.21)中的余项 $\frac{1}{2}\|\eta\|_{H^1}^2$ 在 $\eta \neq 0$ 时严格为正。所以 E 严格凸，驻点若存在，就是唯一的全局最优解。第 29.2节证明了存在性，这里证明了驻点即最优，两者合起来，驻定方程的解就是答案。

二阶变化 没有凸性时，要看二阶信息。沿直线，$\phi''(0)$ 就是二阶变化。

定义 29.14 二阶变分 若 $\phi(t) = J(u+t\eta)$ 在 $t=0$ 的邻域内二阶可导，称

$$\delta^2 J(u;\eta) = \phi''(0) \tag{29.30}$$

为 J 在 u 处沿 η 的**二阶变分**（second variation）。

若 $u^\star$ 是子空间方向上的局部极小点，则 ϕ 在 $t=0$ 处局部极小，所以 $\phi'(0)=0$，并有 $\phi''(0) \ge 0$。这是二阶必要条件：$\delta^2 J(u^\star;\eta) \ge 0$，对每个 $\eta \in \boldsymbol{V}$ 成立。

用坐标看二阶变分 目标 (29.14)是二次的，$\phi(t) = t^2 J_\rho(\eta)$，所以

$$\delta^2 J_\rho(0;\eta) = \int_0^1 \left(\eta'^2 - \rho\eta^2\right) \mathrm{d}x.$$

把 $\eta \in H_0^1(0,1)$ 按标准正交基 $\sqrt{2}\sin(k\pi x)$ 展开，系数为 a_k。由 Parseval 等式，$\|\eta\|_2^2 = \sum_k a_k^2$。

对 η'，它按 $\sqrt{2}\cos(k\pi x)$ 展开的系数，由分部积分（边界项因 η 在端点为零而消失）等于 $k\pi a_k$；它与常数函数的内积是 $\eta(1)-\eta(0)=0$。所以 $\|\eta'\|_2^2 = \sum_k (k\pi)^2 a_k^2$。三角函数系的完备性可参考卷四第 14 章“Fourier 变换”。代入得到

$$\delta^2 J_\rho(0;\eta) = \sum_{k=1}^{\infty} \left((k\pi)^2 - \rho\right) a_k^2. \tag{29.31}$$

这是无限维中的对角二次型，图 29.16(a) 是 $\rho = 15$ 时的对角元。只有 $k=1$ 为负，所以 $u=0$ 是鞍点。对角元有下界但无上界，这是有限维

Hessian 没有的现象：图 29.16(b) 中，把问题离散后，最大特征值约为 $4n^2$，随网格加密趋于无穷，最小特征值停在 π^2 附近。

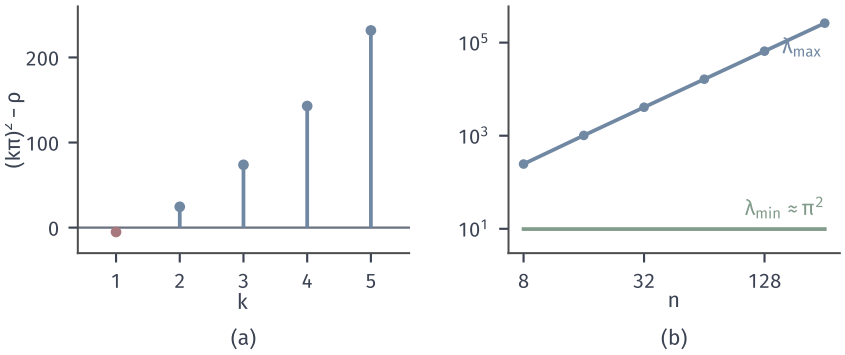


图 29.16 目标 (29.14)的二阶信息。(a)$\rho = 15$ 时式 (29.31)的对角元，红色为负曲率方向 $k = 1$。(b) 二阶差分矩阵的最大特征值（蓝）随段数 n 按 $4n^2$ 增长，最小特征值（绿）停在 π^2 附近，所以 L^2 意义下没有有限的光滑常数 L。

由式 (29.31)可以读出全部结论。$\rho < \pi^2$ 时每个对角元为正，J_ρ 严格凸，$u = 0$ 是唯一的最优解。$\rho = \pi^2$ 时 $t \sin \pi x$ 全是最优解，解不唯一。$\rho > \pi^2$ 时目标无下界。这也给出了精确的 Poincaré 不等式：

$$\|\eta'\|_2^2 \geq \pi^2 \|\eta\|_2^2.$$

处处为正不够 有限维中，Hessian 正定就足以保证严格局部极小，因为单位球面紧，正定函数在其上有正的最小值 μ。无限维中球面不紧，这个最小值可以是 0。

在 ℓ^2 上，也就是把函数看成坐标序列，令

$$J(\boldsymbol{a}) = \sum_{k=1}^{\infty} \Big(\frac{a_k^2}{k^2} - a_k^4 \Big).$$

由 $\sum_k a_k^4 \leq \|\boldsymbol{a}\|_2^4$，$J$ 处处有限。在原点，J 的一阶微分为零，二阶变分 $\delta^2 J(\mathbf{0}; \boldsymbol{\eta}) = 2 \sum_k \eta_k^2 / k^2$，对每个 $\boldsymbol{\eta} \neq \mathbf{0}$ 都是正的。

但取只有第 k 个坐标非零的点 $\boldsymbol{a}^{(k)} = \frac{2}{k} \boldsymbol{e}_k$，有

$$\|\boldsymbol{a}^{(k)}\|_2 = \frac{2}{k} \to 0, \qquad J(\boldsymbol{a}^{(k)}) = \frac{4}{k^4} - \frac{16}{k^4} = -\frac{12}{k^4} < 0.$$

所以原点不是局部极小点。曲率 $2/k^2$ 沿高频坐标趋于零，四次项就占了上风。要恢复有限维的结论，必须要求曲率有统一的正下界。

定理 29.15 二阶充分条件 设 $\boldsymbol{C} = u_0 + \boldsymbol{V}$，$J$ 在 $u^\star \in \boldsymbol{C}$ 的邻域内二阶连续 Fréchet 可微，$DJ(u^\star)$ 在 $\boldsymbol{V}$ 上为零，且存在 $\mu > 0$ 使

$$D^2J(u^\star)[\eta,\eta] \geq \mu\|\eta\|^2 \qquad (\eta \in \boldsymbol{V}). \tag{29.32}$$

则 $u^\star$ 是所用范数下的严格局部极小点。

证明 由连续性，取 $r > 0$，使 $\|v - u^\star\| < r$ 时 $\|D^2J(v) - D^2J(u^\star)\| \leq \mu/2$。对 $\eta \in \boldsymbol{V}$，$0 < \|\eta\| < r$，用带积分余项的 Taylor 公式，一阶项为零，

$$J(u^\star + \eta) - J(u^\star) = \int_0^1 (1-\tau) D^2J(u^\star + \tau\eta)[\eta,\eta]\,\mathrm{d}\tau.$$

被积式中的二阶微分不小于 $\mu\|\eta\|^2 - \frac{\mu}{2}\|\eta\|^2$，所以

$$J(u^\star + \eta) - J(u^\star) \geq \frac{\mu}{4}\|\eta\|^2 > 0.$$

■

上面的 ℓ^2 反例不满足式 (29.32)。而 J_ρ 在 $0 \leq \rho < \pi^2$ 时满足它：由式 (29.31)，在范数 $\|\eta'\|_2$ 下，$\mu = 1 - \rho/\pi^2$。条件是否成立同样依赖范数：同一个二阶变分在 H^1 范数下是强制的，在更强的范数下可能不是。

约束乘子 若约束不是仿射的，第 17章的乘子法则还成立吗？有限个约束时答案是肯定的，因为证明可以化归到有限维。

定理 29.16 有限个等式约束的乘子法则 设 X 是 Banach 空间，$u^\star$ 是 J 在约束 $h_j(u) = 0$（$j = 1,\dots,p$）下某范数的局部极小点。设 $J, h_1, \dots, h_p$ 在 $u^\star$ 的邻域内连续 Fréchet 可微，且 $Dh_1(u^\star), \dots, Dh_p(u^\star)$ 线性无关。则存在唯一的 $\boldsymbol{\nu} \in \mathbb{R}^p$，使

$$DJ(u^\star) + \sum_{j=1}^{p} \nu_j Dh_j(u^\star) = 0 \quad \text{于 } X^*. \tag{29.33}$$

证明 选取补方向。由线性无关，存在 $e_1, \dots, e_p \in X$，使 $Dh_i(u^\star)[e_j]$ 当 $i = j$ 时为 1，否则为 0。记 $\boldsymbol{N}$ 为全部 $Dh_j(u^\star)$ 的公共零空间。

化到有限维。固定 $\eta \in \boldsymbol{N}$，考虑从 $\mathbb{R}\times\mathbb{R}^p$ 到 $\mathbb{R}^p$ 的映射

$$\Psi_j(t,\boldsymbol{s}) = h_j\Big(u^\star + t\eta + \sum_{i=1}^{p} s_i e_i\Big).$$

在原点 $\boldsymbol{\Psi}$ 取零，对 $\boldsymbol{s}$ 的 Jacobi 矩阵是单位阵。由隐函数定理，存在 $\boldsymbol{s}(0)=\mathbf{0}$ 的 C^1 函数 $\boldsymbol{s}(t)$，使约束沿 t 始终成立。

对 t 求导，并用 $Dh_j(u^\star)[\eta]=0$，得到

$$\boldsymbol{s}'(0) = \mathbf{0}.$$

沿可行曲线求导。令 $w(t)=u^\star+t\eta+\sum_i s_i(t)e_i$，它可行，$w(0)=u^\star$，$w'(0)=\eta$。一元函数 $J(w(t))$ 在 $t=0$ 处局部极小，所以导数为零，即 $DJ(u^\star)[\eta]=0$。

写出乘子。令 $\nu_j = -DJ(u^\star)[e_j]$。对任意 $v\in X$，$v-\sum_j Dh_j(u^\star)[v]\,e_j$ 属于 $\boldsymbol{N}$，代入上一步得到

$$DJ(u^\star)[v] = -\sum_{j=1}^{p} \nu_j Dh_j(u^\star)[v].$$

这就是式 (29.33)。唯一性由线性无关得到。 ∎

关键在于约束只有有限个，隐函数定理只用在 $\mathbb{R}^p$ 上。条件中的连续 Fréchet 可微和线性无关都依赖所选的空间。

一个可以手算的乘子　一根两端固定的细线绕过中点处高度为 1 的钉子。写成问题，就是

$$\min\ \frac{1}{2}\int_0^1 u'(x)^2\,\mathrm{d}x, \qquad u\in H^1_0(0,1),\quad u\big(\tfrac12\big)\ge 1.$$

点值读取在 H^1 中连续，由式 (29.6)，这个约束是良定义的。候选是图 29.17(a) 的折线 $u^\star = 2\min\{x,1-x\}$。

直接计算微分：把积分在 $x=\frac12$ 处分开，

$$DJ(u^\star)[\eta] = 2\int_0^{1/2}\eta'\,\mathrm{d}x - 2\int_{1/2}^{1}\eta'\,\mathrm{d}x = 4\,\eta\big(\tfrac12\big).$$

可行集是凸集。对可行的 v，有 $v(\frac12)\ge 1 = u^\star(\frac12)$，所以

$$DJ(u^\star)[v-u^\star] = 4\big(v(\tfrac12)-1\big)\ge 0.$$

由定理 29.13，$u^\star$ 是全局最优解，$J^\star = \frac{1}{2}\cdot 4 = 2$。

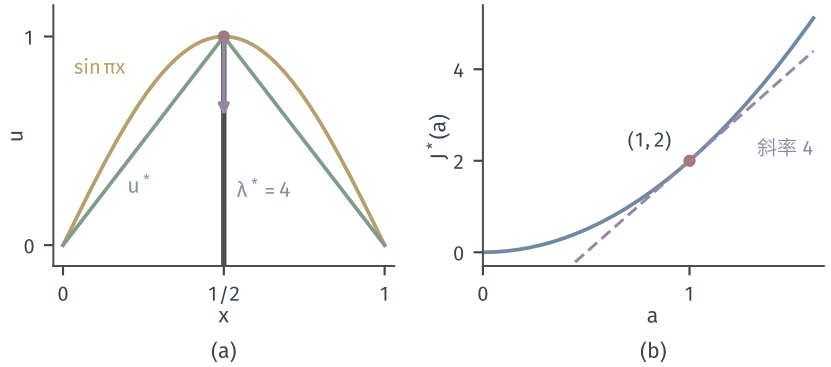


图 29.17　钉子问题。(a) 深灰竖线是钉子，绿色折线是最优解，黄色 $\sin \pi x$ 是另一个可行候选（能量 $\pi^2/4 \approx 2.47$，大于 2），紫色箭头表示乘子 $\lambda^\star = 4$。(b) 钉子高度为 a 时的最优值 $J^\star(a) = 2a^2$，$a = 1$ 处切线（紫色虚线）的斜率等于乘子。

把约束写成 $g(u) = 1 - u(\frac{1}{2}) \le 0$，于是 $Dg[\eta] = -\eta(\frac{1}{2})$。平稳条件 $DJ(u^\star) + \lambda Dg = 0$ 给出乘子

$$\lambda^\star = 4 \ge 0.$$

乘子仍是影子价格。钉子高度为 a 时，最优解是 $2a\min\{x, 1-x\}$，最优值是 $J^\star(a) = 2a^2$，在 $a = 1$ 处的导数正是 4，见图 29.17(b)。把高度抬高一点，能量按每单位高度 4 增加。

这个乘子也可以用梯度来读。在内积 $\int v'\eta'$ 下，读取 $\eta \mapsto \eta(\frac{1}{2})$ 的梯度是 $w = \frac{1}{2}\min\{x, 1-x\}$，因为 $\int_0^1 w'\eta'\,\mathrm{d}x = \eta(\frac{1}{2})$。而 $\nabla J(u^\star) = u^\star = 4w$。目标的梯度等于乘子乘以约束的梯度，这与有限维的几何完全相同。

乘子的适用前提　上面的例子只有一个约束。若要求 $u(x) \ge \psi(x)$ 对每个 x 成立，约束就有无穷多个，定理 29.16用不上。乘子要变成对偶空间中的元素，它通常不是函数。把钉子看成这种情形，乘子是中点处的点质量 $4\delta_{1/2}$，u' 在钉子处恰好跳变 -4。

无穷约束下乘子的存在，需要 Slater 型条件，也就是可行集在合适拓扑中有内点。这时拓扑的选择又起决定作用：L^2 中非负函数组成的锥没有内点，因为从任何非负函数减去一个窄而高的尖峰，都可以用任意小的 L^2 范数变成在一小段上为负。而 $C[0,1]$ 中 $u \ge \varepsilon > 0$ 的函数是内点。一维时 H^1 的范数控制上确界，内点也存在；高维时这一点不再成立，需要在具体问题中重新论证。

29.1 泛函优化问题
29.2 极小值的存在
29.3 泛函的微分
29.4 最优解的判别
29.5 积分泛函
29.5.1 Euler–Lagrange 方程
29.5.2 自由边界条件
29.6 有限维近似
29.7 本章小结

所以，有限维的乘子法则搬到函数空间时要检查三件事：约束是有限个还是无穷个，约束在所选范数下是否可微，约束规范在所选拓扑下是否成立。

29.5 积分泛函

前几节的目标 E 和 ℓ 都是沿区间累加一个局部代价。于是要问：对这一类目标，最优性条件具体是什么？答案是一个常微分方程，加上由约束决定的边界条件。

设 $F(x,s,p)$ 是定义在 $[a,b]\times\mathbb{R}\times\mathbb{R}$ 上的函数，称为**密度**（density），对 (s,p) 连续可微，偏导数连续。**积分泛函**（integral functional）是

$$J(u)=\int_a^b F\bigl(x,u(x),u'(x)\bigr)\,\mathrm{d}x. \tag{29.34}$$

下面用 F_s,F_p 表示 F 对第二、第三个变量的偏导数，沿候选求值时省略自变量，即 F_p 表示 $F_p(x,u(x),u'(x))$，它是 x 的函数。F_p 是对“斜率所在的变量”求偏导，不是对函数 u' 求导。

一阶变分 沿直线 $u+t\eta$ 求导，只需把导数换到积分号内。

定理 29.17 积分泛函的一阶变分 设 $u,\eta\in C^1[a,b]$。则

$$J'(u;\eta)=\int_a^b \bigl(F_s\,\eta+F_p\,\eta'\bigr)\,\mathrm{d}x. \tag{29.35}$$

证明 函数 $(x,t)\mapsto F(x,u+t\eta,u'+t\eta')$ 对 t 的偏导数是 $F_s\eta+F_p\eta'$ 在点 $(x,u+t\eta,u'+t\eta')$ 的值，它在紧集 $[a,b]\times[-1,1]$ 上连续。连续偏导数允许在积分号下求导，令 $t=0$ 即得。 ∎

这也是方向导数的线性公式。$J'(u;\eta)$ 对 η 线性，并被 η 的 C^1 范数控制。对 Sobolev 函数，要在积分号下求导还需要控制收敛定理所要求的可积上界，要根据 F 的增长条件逐项核对；E 和 ℓ 的情形已由第 29.3.1节的展开直接得到。

29.1 泛函优化问题
29.2 极小值的存在
29.3 泛函的微分
29.4 最优解的判别
29.5 积分泛函
29.5.1 Euler–Lagrange 方程
29.5.2 自由边界条件
29.6 有限维近似
29.7 本章小结

29.5.1 Euler–Lagrange 方程

用分部积分消去 η' 一阶变分同时含 η 和 η'，而它们不是独立的。为了让式子只含 η，把 η' 前的系数移走。设 $u \in C^2[a,b]$，F 二阶连续可微，分部积分得到

$$J'(u;\eta) = \int_a^b \Big(F_s - \frac{\mathrm{d}}{\mathrm{d}x}F_p\Big)\eta \,\mathrm{d}x + \Big[F_p\,\eta\Big]_a^b. \tag{29.36}$$

边界项先记下来。固定端点时，可行扰动在两端为零，边界项消失。第 29.5.2小节放开端点时，这一项会成为主角。

此时括号里的函数在 L^2 内积下正是 J 的梯度。由第 29.3.2小节，E 在 $u = x$ 处的 L^2 梯度是 x，这里 $-u'' + u = x$，两者一致。驻定条件要求这个梯度与所有扰动正交，接下来把“正交于所有扰动”变成“等于零”。

变分基本引理 在有限维中，若 $\boldsymbol{g}^{\mathsf{T}}\boldsymbol{d} = 0$ 对每个 $\boldsymbol{d}$ 成立，取 $\boldsymbol{d} = \boldsymbol{g}$ 得 $\boldsymbol{g} = \boldsymbol{0}$。函数空间里扰动有端点和光滑性要求，不能直接取 $\eta = g$，但可以取一个局部的小凸起，见图 29.18。

> **引理 29.18　变分基本引理** 设 $g \in C[a,b]$，且对每个在 (a,b) 内紧支撑的光滑函数 η 都有 $\int_a^b g\,\eta\,\mathrm{d}x = 0$。则 $g \equiv 0$。

> **证明** 设有 $x_0 \in (a,b)$ 使 $g(x_0) > 0$，$g(x_0) < 0$ 的情形相同。由连续性，存在 $r > 0$，使 $(x_0 - r, x_0 + r) \subset (a,b)$，且 g 在其上为正。取 η 为支撑在这个区间内的非负光滑函数，例如当 $|x - x_0| < r$ 时
>
> $$\eta(x) = \exp\!\Big(\frac{-1}{1 - (x - x_0)^2/r^2}\Big),$$
>
> 其余位置为零。则 $g\eta \geq 0$，在 x_0 处严格为正，于是积分为正，与假设矛盾。所以 g 在 (a,b) 内为零，由连续性在端点也为零。 ∎

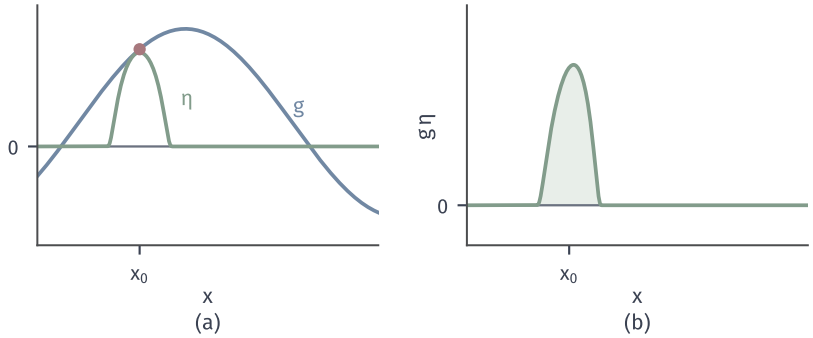


图 29.18 变分基本引理的构造。(a) 蓝色 g 在红点 x_0 处为正，绿色凸起 η 只在 $g>0$ 的小区间内非零。(b) 乘积 $g\eta$ 非负，积分严格为正，所以 g 不能与所有扰动正交。

把扰动限制在局部，等于“单独改动一小段曲线”。这是向量情形“单独改动一个坐标”的连续版本：极小点处每一小段都不能再改进，方程因此对每个 x 成立。

定理 29.19 Euler–Lagrange 方程 设 F 二阶连续可微，$u\in C^2[a,b]$ 满足 $u(a)=\alpha$，$u(b)=\beta$，并且在固定端点的 C^1 函数中，是 C^1 范数下 J 的局部极小点。则对每个 $x\in[a,b]$，

$$\frac{\mathrm{d}}{\mathrm{d}x}F_p\big(x,u(x),u'(x)\big)=F_s\big(x,u(x),u'(x)\big). \tag{29.37}$$

证明 可行方向是端点为零的 C^1 函数，它们组成子空间，由定理 29.12得 $J'(u;\eta)=0$。式 (29.36)的边界项为零，再由引理 29.18，括号内的连续函数恒为零。 ∎

式 (29.37)称为Euler–Lagrange 方程（Euler–Lagrange equation），它的解称为**极值曲线**（extremal）。这个名称有些误导，因为解不一定是极值，下面专门讨论这一点。

两个例子 对长度目标 (29.2)，$F=\sqrt{1+p^2}$ 不依赖 s，所以 $F_s=0$，方程 (29.37)说 F_p 是常数：

$$\frac{u'(x)}{\sqrt{1+u'(x)^2}}=c.$$

函数 $p\mapsto p/\sqrt{1+p^2}$ 严格递增，所以 u' 是常数，u 是直线。加上端点条件得 $u(x)=x$，$\ell^\star=\sqrt{2}$。

对能量 (29.3)，$F=\tfrac12 p^2+\tfrac12 s^2$，$F_p=p$，$F_s=s$，方程是

$$u''=u,\qquad u(0)=0,\ u(1)=1. \tag{29.38}$$

通解是 $A\sinh x + B\cosh x$，由 $u(0)=0$ 得 $B=0$，由 $u(1)=1$ 得 $A = 1/\sinh 1$，于是

$$u^\star(x) = \frac{\sinh x}{\sinh 1}. \tag{29.39}$$

这就是第 29.3.2小节由一步梯度得到的曲线。由 $u''=u$，有 $u'^2+u^2=(uu')'$，积分得到最优值

$$E^\star = \frac{1}{2}\big[uu'\big]_0^1 = \frac{1}{2}u'(1) = \frac{1}{2}\coth 1 \approx 0.6565. \tag{29.40}$$

E 严格凸，由定理 29.13，$u^\star$ 就是唯一的全局最优解。

函数要有多光滑 推导用了 $u\in C^2$，它只是为了分部积分。候选只有 C^1 时，换一个方向分部积分，把导数放到 F_s 的原函数上。令 $A(x)=\int_a^x F_s\,\mathrm{d}\tau$，它是 C^1 函数。分部积分，由 η 在端点为零得到

$$\int_a^b F_s\eta\,\mathrm{d}x = -\int_a^b A\eta'\,\mathrm{d}x.$$

于是驻定条件变成

$$\int_a^b (F_p - A)\,\eta'\,\mathrm{d}x = 0 \qquad \text{对端点为零的 } \eta\in C^1.$$

下面的引理把这个条件化成 $F_p - A$ 是常数。设 $g\in C[a,b]$ 满足 $\int_a^b g\eta'\,\mathrm{d}x=0$。令 c 为 g 的平均值，取 $\eta(x)=\int_a^x(g-c)\,\mathrm{d}\tau$，它在两端为零，由 $\int_a^b \eta'\,\mathrm{d}x=0$ 得到

$$\int_a^b (g-c)^2\,\mathrm{d}x = \int_a^b (g-c)\eta'\,\mathrm{d}x = \int_a^b g\eta'\,\mathrm{d}x = 0.$$

所以 $g\equiv c$。这一结论称为 du Bois-Reymond 引理。把它用在 $g=F_p-A$ 上，得到积分形式的方程

$$F_p\big(x,u(x),u'(x)\big) = c + \int_a^x F_s\,\mathrm{d}\tau. \tag{29.41}$$

右端是 C^1 的，所以 F_p 沿曲线可导且满足式 (29.37)，虽然 u'' 可能不存在。若 $F_{pp}>0$，由隐函数定理可从 F_p 解出 u'，u 自动属于 C^2。

式 (29.41)对分段 C^1 的候选同样成立，而右端连续，所以在曲线的折点处，F_p 不能跳变。这是极值曲线可以有折点的唯一条件。对 $G(p)=(p^2-1)^2$，$F_p=4p(p^2-1)$ 在 $p=\pm1$ 处都为零，所以斜率 ±1 的锯齿满足这个条件。而钉子问题中 $F_p=u'$ 在中点跳变，因为那里的扰动受到约束，驻定条件只对 $\eta(\frac12)=0$ 的方向成立，跳变的幅度 4 正是乘子。

对 H^1 中的极小点，能直接得到的只有弱形式：$\int_a^b (F_s\eta + F_p\eta')\,\mathrm{d}x = 0$。极小点是否足够光滑从而满足方程的经典形式，是方程理论的正则性问题，可参考卷六第 4 章“椭圆方程与边值问题”。

方程是必要条件　式 (29.37)由“若是局部极小点”推出，反过来不成立。对目标 (29.14)，$F_p = p$，$F_s = -\rho s$，方程是 $u'' + \rho u = 0$，$u = 0$ 总是解。而第 29.4节已经算出，$\rho > \pi^2$ 时 $u = 0$ 是鞍点，目标甚至无下界。

要断定一个解是极小点，有两条路。若 F 对 (s, p) 联合凸，则 J 是凸泛函，由定理 29.13，满足端点条件和方程的 u 就是全局最优解，这是 E 和 ℓ 的情形。没有凸性时，要检查二阶变分，它的积分形式是

$$\delta^2 J(u;\eta) = \int_a^b \left(F_{ss}\,\eta^2 + 2F_{sp}\,\eta\eta' + F_{pp}\,\eta'^2\right)\mathrm{d}x. \tag{29.42}$$

二阶必要条件的局部形式　式 (29.42)中哪一项决定符号？取一个窄的帐篷形扰动，半宽和高度都是 ε，斜率为 ± 1。η^2 项的量级是 ε^3，$\eta\eta'$ 项是 ε^2，η'^2 项是 ε。ε 很小时，F_{pp} 的项占主导，高频扰动只看得见 F_{pp}。

定理 29.20　Legendre 条件　设 F 二阶连续可微，$u \in C^1[a,b]$ 是固定端点问题在 C^1 范数下的局部极小点。则对每个 $x \in [a,b]$，

$$F_{pp}\big(x, u(x), u'(x)\big) \geq 0. \tag{29.43}$$

证明　设在内点 x_0 处 $F_{pp} < 0$，端点的情形由连续性归结到内点。由连续性，存在 $c > 0$ 和 $\varepsilon_0 > 0$，使 $|x - x_0| \leq \varepsilon_0$ 时 $F_{pp} \leq -c$。对 $\varepsilon < \varepsilon_0$ 取上述帐篷形扰动，把折点磨圆使之成为 C^1 函数，磨圆可以使下列估计的改变任意小。由式 (29.42)，存在只依赖 F 和 u 的常数 M，使

$$\delta^2 J(u;\eta) \leq -2c\,\varepsilon + M\varepsilon^2.$$

ε 足够小时右端为负，与二阶必要条件矛盾。 ∎

对目标 (29.13)，$G''(0) = -4 < 0$，所以 $u = 0$ 不是局部极小点，这与第 29.2节的观察一致：G 在 0 附近非凸，锯齿能把目标压低。Legendre 条件仍只是必要的。目标 (29.26)在 $u = 0$ 处 $F_{pp} = 2 > 0$，$u = 0$ 在 C^1 范数下也确实是局部极小点，但在上确界范数下不是。

29.1 泛函优化问题
29.2 极小值的存在
29.3 泛函的微分
29.4 最优解的判别
29.5 积分泛函
29.5.1 Euler–Lagrange 方程
29.5.2 自由边界条件
29.6 有限维近似
29.7 本章小结

向量值函数与多元区域 方程可以逐分量推广。若未知量是向量值函数 $\boldsymbol{u}:[a,b]\to\mathbb{R}^r$，密度为 $F(x,\boldsymbol{s},\boldsymbol{p})$，每次只扰动一个分量，重复上面的论证，得到方程组

$$\frac{\mathrm{d}}{\mathrm{d}x}\nabla_{\boldsymbol{p}}F=\nabla_{\boldsymbol{s}}F. \tag{29.44}$$

若未知量是区域 $\Omega\subset\mathbb{R}^d$ 上的函数，目标是

$$J(u)=\int_{\Omega}F(\boldsymbol{x},u,\nabla u)\,\mathrm{d}\boldsymbol{x},$$

分部积分换成散度定理，方程变为

$$\operatorname{div}\bigl(\nabla_{\boldsymbol{p}}F\bigr)=F_{s}. \tag{29.45}$$

例如 $F=\frac{1}{2}\|\boldsymbol{p}\|_2^2-g(\boldsymbol{x})s$ 给出 $-\Delta u=\mathrm{g}$。这些方程的解的理论不属于本章。

29.5.2 自由边界条件

至此端点都是固定的。若端点可以移动，可行扰动就变多了，最优解要多满足一些条件。本小节要回答的问题是：多出来的扰动告诉我们什么？关键是重新核对式 (29.36)中的边界项。

放开一个端点的值 把例子改成：保留 $u(1)=1$，$u(0)$ 不作约束。候选在 $\boldsymbol{C}=\{u\in H^1(0,1):u(1)=1\}$ 中，扰动只需 $\eta(1)=0$。设 $u\in C^2$ 是极小点，推理分两步。

第一步，固定端点的扰动仍然允许。取两端为零的 η，同样得到内部方程 (29.37)，u 仍满足它。第二步，把这个结论代回式 (29.36)，积分项消失，只剩边界项。由 $\eta(1)=0$，

$$0=J'(u;\eta)=\bigl[F_p\eta\bigr]_0^1=-F_p\bigl(0,u(0),u'(0)\bigr)\,\eta(0).$$

$\eta(0)$ 可以取任意值，所以

$$F_p\bigl(0,u(0),u'(0)\bigr)=0. \tag{29.46}$$

这样的条件称为**自然边界条件**（natural boundary condition），它不是提问时写下的，而是由优化自己产生的。若继续沿用固定端点的公式，方程少一个边界条件，解就不确定。第二步的逻辑也不能颠倒：必须先用内部扰动消去积分项，边界项才能单独出现。

对 E，$F_p=u'$，条件是 $u'(0)=0$。方程 $u''=u$ 加上 $u'(0)=0$，$u(1)=1$，解得

$$u^{\star}(x)=\frac{\cosh x}{\cosh 1}. \tag{29.47}$$

同样用 $u'^2 + u^2 = (uu')'$ 积分，边界项中 $u'(0) = 0$，得到最优值

$$E^\star = \frac{1}{2}u(1)u'(1) = \frac{1}{2}\tanh 1 \approx 0.3808.$$

它比固定端点的 0.6565 小，因为可行集变大了。图 29.19(a) 的绿线就是这个解，它在 $x = 0$ 处水平。

边界代价 固定端点和自由端点是一族问题的两个极端。在左端加上代价 $\frac{\beta}{2}u(0)^2$，$\beta \ge 0$，目标为

$$J_\beta(u) = E(u) + \frac{\beta}{2}u(0)^2, \qquad u(1) = 1. \tag{29.48}$$

边界代价的微分是 $\beta u(0)\eta(0)$，它和边界项 $-F_p\eta(0)$ 相加，给出

$$F_p\big(0, u(0), u'(0)\big) = \beta\, u(0). \tag{29.49}$$

对 E，这就是 $u'(0) = \beta u(0)$。解 $u'' = u$，得到

$$u_\beta(x) = \frac{\cosh x + \beta \sinh x}{\cosh 1 + \beta \sinh 1}.$$

积分后，边界代价正好抵消左端的边界项，最优值为

$$J^\star_\beta = \frac{1}{2}u'_\beta(1) = \frac{1}{2}\cdot\frac{\sinh 1 + \beta\cosh 1}{\cosh 1 + \beta \sinh 1}.$$

$\beta = 0$ 回到自然边界，$J^\star_0 = \frac{1}{2}\tanh 1$；$\beta \to \infty$ 时 $u_\beta(0) \to 0$，回到固定端点，$J^\star_\beta \to \frac{1}{2}\coth 1$。图 29.19显示了这一过渡。固定端点相当于“价格无穷大”的边界代价。

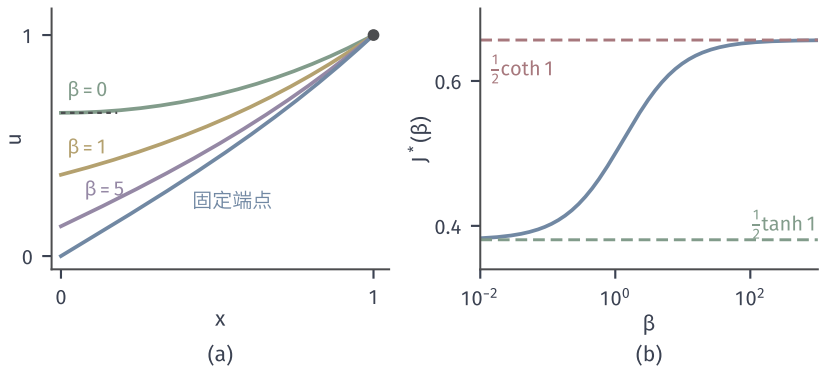


图 29.19 从自然边界到固定端点。(a)$u(1) = 1$（灰点）时，$\beta = 0, 1, 5$ 的解和固定端点 $u(0) = 0$ 的解（蓝）；绿线在 $x = 0$ 处水平，短虚线是水平切线。(b) 最优值 $J^\star_\beta$ 随 β 从 $\frac{1}{2}\tanh 1$ 上升到 $\frac{1}{2}\coth 1$。

端点沿曲线移动 更一般地，端点的横坐标也可以动。设左端固定在 (a,α)，右端点要落在给定曲线 $y=\psi(x)$ 上，未知量是函数 u 和右端横坐标 b。这时积分上限也在变，式 (29.36)要重新推导。

取一族可行的 (u_t, b_t)，$t=0$ 时为 (u,b)，记 $\eta=\partial_t u_t|_{t=0}$，$\tau=\dot b_t|_{t=0}$。这里 u 在 b 的右侧邻域内也有定义，u_t 在其上可导。对积分上限和被积函数分别求导，得到

$$\frac{\mathrm{d}}{\mathrm{d}t}J\Big|_{t=0} = F\big(b,u(b),u'(b)\big)\tau + \int_a^b \big(F_s\eta + F_p\eta'\big)\,\mathrm{d}x.$$

约束 $u_t(b_t)=\psi(b_t)$ 对 t 求导，把端点的两种移动联系起来：

$$\eta(b) + u'(b)\tau = \psi'(b)\tau.$$

内部方程仍然成立，因为固定 b 和端点值的扰动仍然允许。代入分部积分，并用 $\eta(a)=0$，积分项消失，只剩 $F\tau + F_p\eta(b)$。把上式解出的 $\eta(b)=(\psi'(b)-u'(b))\tau$ 代入，由 τ 可以任意取，得到

$$F + \big(\psi' - u'\big)F_p = 0 \qquad \text{在 } x=b. \tag{29.50}$$

这是**横截条件**（transversality condition）。它有别于式 (29.46)，因为这里多了由积分上限移动产生的 $F\tau$。

用最短曲线检验。对 $F=\sqrt{1+p^2}$，式 (29.50)化简为

$$\frac{1+\psi'(b)\,u'(b)}{\sqrt{1+u'(b)^2}} = 0,$$

即 $\psi'(b)\,u'(b)=-1$。极值曲线是直线，所以结论是：从一点到一条曲线的最短线段垂直于这条曲线。图 29.20中，曲线是 $\psi(x)=2-x$，斜率 -1，于是 $u'=1$。从原点出发的直线 $y=x$ 在 $(1,1)$ 处与之相交，长度 $\sqrt{2}$。

29.1 泛函优化问题
29.2 极小值的存在
29.3 泛函的微分
29.4 最优解的判别
29.5 积分泛函
29.6 有限维近似
29.7 本章小结

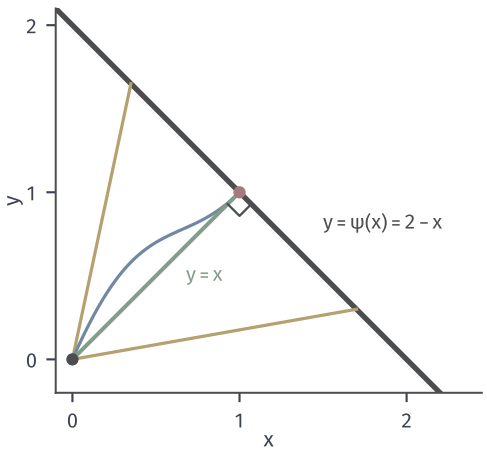


图 29.20 端点沿曲线移动时的最短曲线。深灰粗线是端点可落的直线 $y = 2 - x$，绿色线段是解，在红点 $(1,1)$ 处与之垂直，长度 $\sqrt{2} \approx 1.414$。黄色线段端点分别在 $x = 0.35$ 和 $x = 1.7$ 处，长度分别约为 1.69 和 1.73；蓝色曲线到同一终点，也比直线长。

多元区域的边界 在区域 Ω 上，分部积分换成散度定理，边界项变成边界积分 $\int_{\partial\Omega} (\nabla_{\boldsymbol{p}} F \cdot \boldsymbol{n})\,\eta\,\mathrm{d}S$，$\boldsymbol{n}$ 是外法向量。边界分成两部分时，固定值的部分上 $\eta = 0$，放开的部分上，同样的两步推理给出 $\nabla_{\boldsymbol{p}} F \cdot \boldsymbol{n} = 0$。对 $F = \frac{1}{2}\|\boldsymbol{p}\|_2^2$，这就是法向导数为零。

各种边界情形可以总结成一张表，共同的来源都是式 (29.36)的边界项。

表 29.4 一维问题右端的三种边界情形，左端符号相反。

端点情形	允许的扰动	边界条件
固定 $u(b) = \beta$	$\eta(b) = 0$	$u(b) = \beta$
放开 $u(b)$	$\eta(b)$ 任意	$F_p = 0$
放开并加代价 $\Phi(u(b))$	$\eta(b)$ 任意	$F_p + \Phi'(u(b)) = 0$
沿曲线 $y = \psi(x)$ 移动	$\eta(b) = (\psi' - u')\tau$	$F + (\psi' - u')F_p = 0$

29.6 有限维近似

Euler–Lagrange 方程只在少数情形下能解出来。接下来要弄清：怎样把函数问题换成可计算的有限维问题，换完之后算出来的东西离真解有多远？本节开头的向量类比在这里变成计算方法。

主要思想 可行集 $\boldsymbol{C} = u_0 + \boldsymbol{V}$ 太大，就在其中挑一个有限维的小块。取线性无关的**试探函数**（trial function）$\phi_1, \dots, \phi_r \in \boldsymbol{V}$，令 $\boldsymbol{V}_n$ 是它们张成的子空间，只在

$$\boldsymbol{C}_n = u_0 + \boldsymbol{V}_n \tag{29.51}$$

中比较候选。$\boldsymbol{V}_n$ 称为**试探空间**（trial space），n 表示近似的精细程度。候选由系数向量 $\boldsymbol{c}\in\mathbb{R}^r$ 决定，目标泛函变成普通的多元函数 $f(\boldsymbol{c})=J(u_0+\sum_i c_i\phi_i)$。在试探空间上直接最小化目标的做法称为**Ritz 方法**（Ritz method）。

这样得到的问题前面各章都能解，$\boldsymbol{C}_n\subseteq\boldsymbol{C}$ 也保证了离散最优值不低于 $J^\star$。对二次目标，步骤可以完全写出来。设 $J(u)=\frac{1}{2}a(u,u)-\xi(u)$，$a$ 是对称双线性形式，ξ 是线性泛函。代入并按 $\boldsymbol{c}$ 整理，得到

$$f(\boldsymbol{c})=J(u_0)+\frac{1}{2}\boldsymbol{c}^{\top}\boldsymbol{A}\boldsymbol{c}-\boldsymbol{b}^{\top}\boldsymbol{c},\tag{29.52}$$

其中

$$\boldsymbol{A}_{i,j}=a(\phi_i,\phi_j),\qquad b_i=\xi(\phi_i)-a(u_0,\phi_i).\tag{29.53}$$

若 a 在 $\boldsymbol{V}$ 上正定，$\boldsymbol{A}$ 对称正定，令梯度为零得到唯一的解

$$\boldsymbol{c}=\boldsymbol{A}^{-1}\boldsymbol{b},\qquad \min f=J(u_0)-\frac{1}{2}\boldsymbol{b}^{\top}\boldsymbol{c}.\tag{29.54}$$

最简单的例子只用一个试探函数。对 E 取 $u_0=x$，$\phi_1=x(1-x)$，由式 (29.16)，$A_{1,1}=11/30$，$b_1=-1/12$。于是 $c_1=-5/22$，这正是图 29.9(b) 的最小点。由式 (29.54)，目标值是

$$\frac{2}{3}-\frac{5}{528}=\frac{347}{528}\approx 0.65720.$$

而 $E^\star\approx 0.65652$。一个参数就把目标差从 0.0101 降到 0.0007。

计算过程　下面用分段线性的试探函数，继续计算目标 E，$u(0)=0$，$u(1)=1$。这时 $a(v,w)=\int_0^1(v'w'+vw)\,\mathrm{d}x$，$\xi=0$。

变量

- 段数 n，步长 $\Delta=1/n$，结点 $x_i=i\Delta$。例中 $n=3$，$\Delta=1/3$。
- 帐篷函数 ϕ_i：在结点 x_i 处为 1，其他结点为零，其间线性。自由系数 $\boldsymbol{c}\in\mathbb{R}^r$，$r=n-1$，$c_i$ 就是结点 x_i 的高度。
- 三对角矩阵 $\boldsymbol{A}\in\mathbb{R}^{r\times r}$ 和向量 $\boldsymbol{b}\in\mathbb{R}^r$，由式 (29.53)定义。

初始化　取 u_0 满足边界条件。例中取右端的半个帐篷 $u_0=\phi_3$，它在 $x=1$ 处为 1，在其余结点为零。图 29.21(a) 画了这三个函数。

组装与求解

1. 计算相邻帐篷的内积。每个帐篷的导数是 $\pm1/\Delta$，直接积分得到

$$a(\phi_i,\phi_i)=\frac{2}{\Delta}+\frac{2\Delta}{3},\qquad a(\phi_i,\phi_{i+1})=-\frac{1}{\Delta}+\frac{\Delta}{6},\tag{29.55}$$

不相邻的帐篷内积为零，边界上的半个帐篷 $a(\phi_n,\phi_n)=\frac{1}{\Delta}+\frac{\Delta}{3}$。例中

$$a(\phi_1,\phi_1)=a(\phi_2,\phi_2)=\frac{56}{9},\qquad a(\phi_1,\phi_2)=-\frac{53}{18},\qquad a(\phi_3,\phi_3)=\frac{28}{9}.$$

2. 由式 (29.53)组装。例中 ϕ_3 只和 ϕ_2 相邻，所以

$$\boldsymbol{A}=\begin{bmatrix}56/9 & -53/18\\ -53/18 & 56/9\end{bmatrix},\qquad \boldsymbol{b}=\begin{bmatrix}0\\ 53/18\end{bmatrix}.$$

3. 解线性方程组 $\boldsymbol{A}\boldsymbol{c}=\boldsymbol{b}$。例中两边乘以 18，得到

$$112c_1-53c_2=0,\qquad -53c_1+112c_2=53.$$

由第一式，$c_1=53c_2/112$。代入第二式，解得

$$c_1=\frac{2809}{9735}\approx 0.28855,\qquad c_2=\frac{5936}{9735}\approx 0.60976.$$

4. 由式 (29.54)计算目标值。例中 $J(u_0)=\frac{1}{2}a(\phi_3,\phi_3)=\frac{14}{9}$，于是

$$E_3=\frac{14}{9}-\frac{1}{2}\cdot\frac{53}{18}\cdot\frac{5936}{9735}\approx 0.65786.$$

最终得到结点高度 (0, 0.28855, 0.60976, 1) 的折线。真解在相同结点的值是 0.28892 和 0.61024，$E^\star\approx 0.65652$，见图 29.21(b)。n 增大时，$\boldsymbol{A}$ 是三对角矩阵，每次求解的代价正比于 n。

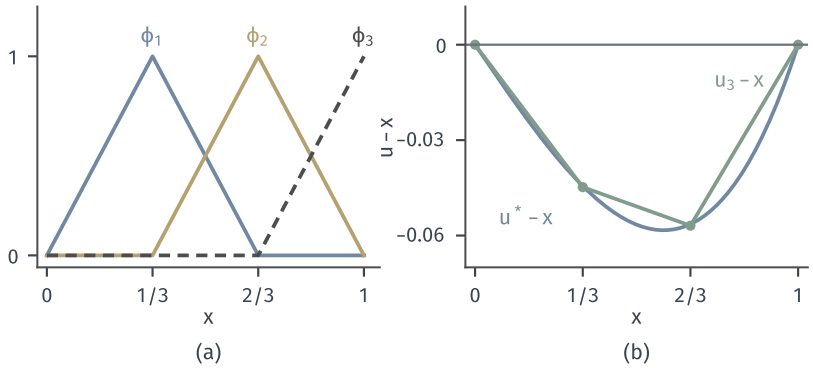


图 29.21 $n=3$ 的 Ritz 方法。(a) 帐篷函数 ϕ_1,ϕ_2 是自由方向，虚线 ϕ_3 用来满足 $u(1)=1$。(b) 为了看清差别，画的是 $u-x$：蓝色为真解，绿色折线为 Ritz 解，结点值接近真解的结点值。

自然边界条件不必写进试探空间 第 29.5.2小节的问题中左端自由。Ritz 方法的处理非常简单：不约束 $x=0$ 处的结点，把 ϕ_0 加入试探函数。条件 $u'(0)=0$ 不写进任何地方。

$n=1$ 时只有一个未知数 $u(0)$，$a(\phi_0,\phi_0)=4/3$，$a(\phi_0,\phi_1)=-5/6$，解得 $u(0)=5/8$。这条直线的斜率不为零，自然条件并不精确成立，它要靠加密来逼近。图 29.22中，$n=3$ 时左端第一段的斜率降到 0.110，$u(0)=0.6457$，真解是 $1/\cosh 1\approx 0.6481$。目标值 0.4063、0.3835 也逐步接近 $E^\star\approx 0.3808$。

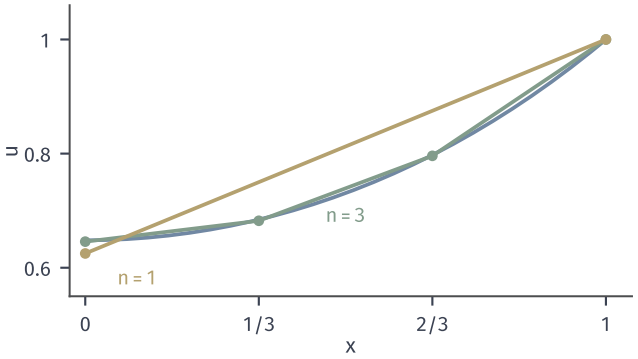


图 29.22　左端自由时的 Ritz 解。蓝色是真解 $\cosh x/\cosh 1$，黄色是 $n=1$，绿色是 $n=3$。试探空间没有写入 $u'(0)=0$，第一段的斜率随加密而趋于零。

先离散再优化，和先写出方程再离散，是两条路线。对 E，后者用差分代替二阶导数，内部结点的方程是 $\frac{1}{\Delta}(-u_{i-1}+2u_i-u_{i+1})+\Delta u_i=0$，而 Ritz 方法的 Δu_i 项换成了 $\frac{\Delta}{6}(u_{i-1}+4u_i+u_{i+1})$。$n=3$ 时，差分解的结点值是 0.28929 和 0.61071，精度相当。差别在于结构：Ritz 方法的矩阵自动对称，目标值从上方逼近 $E^\star$，自然边界条件自动处理；差分方法要为边界单独设计格式。

三种误差　算出的结果与真解的距离由几件不同的事情决定，必须分开。下面逐一说明，它们的区别列在表 29.5中。

第一件事是固定函数能否被逼近：给定一个 $v\in\boldsymbol{C}$，$\boldsymbol{C}_n$ 中有没有函数 v_n，使 $J(v_n)\to J(v)$。这是试探空间和目标的性质，与优化无关。例如 $v=x+\frac{1}{4}\sin 2\pi x$，取它的线性插值 v_n，$|E(v_n)-E(v)|$ 按 n^{-2} 衰减，见图 29.23(a) 的黄线。

第二件事是离散极小者 u_n 是否收敛到真解，这要求 $J(u_n)\to J^\star$，还要求 u_n 本身收敛。它比第一件事多要求目标有存在性论证那样的结构。第三件事是数值求解误差：实际算出的 $\tilde{u}_n$ 与精确的离散极小者 u_n 之间的差。

表 29.5 三种误差。

误差	比较的对象	决定因素
固定函数逼近	$J(v_n)$ 与 $J(v)$	试探空间、J 的连续性
离散极小者收敛	u_n 与 $u^\star$	上一项及存在性结构
数值求解	$\tilde{u}_n$ 与 u_n	算法与迭代步数

二次目标：Ritz 解是能量范数下的最佳逼近 对二次目标，第二件事可以精确回答。目标值的差恰好是一个距离的平方，下面的定理把“目标最小”变成“离真解最近”。

定理 29.21 Ritz 方法的最佳逼近性质 设 $\boldsymbol{V}$ 是 Hilbert 空间，a 是 $\boldsymbol{V}$ 上的对称双线性形式，存在 $0<\mu\le L$，使

$$\mu\|\eta\|^2 \le a(\eta,\eta) \le L\|\eta\|^2 \qquad (\eta\in\boldsymbol{V}), \tag{29.56}$$

并且 $J(u)=\tfrac12 a(u,u)-\xi(u)$ 在 $\boldsymbol{C}=u_0+\boldsymbol{V}$ 上有极小点 $u^\star$。则对 $v\in\boldsymbol{C}$，

$$J(v)-J(u^\star)=\frac12 a(v-u^\star,v-u^\star). \tag{29.57}$$

若 u_n 是 J 在 $\boldsymbol{C}_n=u_0+\boldsymbol{V}_n$ 上的极小点，则

$$a(u_n-u^\star,\,u_n-u^\star)=\min_{v\in\boldsymbol{C}_n} a(v-u^\star,\,v-u^\star), \tag{29.58}$$

并且

$$\|u_n-u^\star\| \le \sqrt{\frac{L}{\mu}}\,\min_{v\in\boldsymbol{C}_n}\|v-u^\star\|. \tag{29.59}$$

证明 令 $\eta=v-u^\star\in\boldsymbol{V}$，把 $J(u^\star+\eta)$ 按 η 展开：

$$J(u^\star+\eta)-J(u^\star)=DJ(u^\star)[\eta]+\frac12 a(\eta,\eta).$$

由式 (29.28)，一次项为零，得到式 (29.57)。

u_n 使左端在 $\boldsymbol{C}_n$ 上最小，也就使 $a(v-u^\star,v-u^\star)$ 最小，这就是式 (29.58)。对任意 $v\in\boldsymbol{C}_n$，由 a 的两个界，

$$\mu\|u_n-u^\star\|^2 \le a(u_n-u^\star,u_n-u^\star) \le a(v-u^\star,v-u^\star) \le L\|v-u^\star\|^2.$$

开方并对 v 取最小，得到式 (29.59)。 ■

式 (29.57)的直观是：能量地形是一只以 $u^\star$ 为底的碗，比较目标值就是比较到碗底的距离。式 (29.58)说明，Ritz 方法不需要事先知道 $u^\star$，却自

动选出了 $u^\star$ 在试探空间中的最佳逼近。在式 (29.3)的例子上，a 就是 H^1 内积，$\mu = L = 1$，Ritz 解是 $u^\star$ 在 H^1 范数下的正交投影。

这也把收敛速度转化成逼近问题。线性元逼近 H^1 函数的误差按 Δ 衰减，目标差是距离的平方，按 Δ^2 衰减。图 29.23(a) 的绿线实测：$n = 16, 32, 64$ 时目标差为 4.79×10^{-5}、1.20×10^{-5}、3.00×10^{-6}，每次缩小到四分之一。

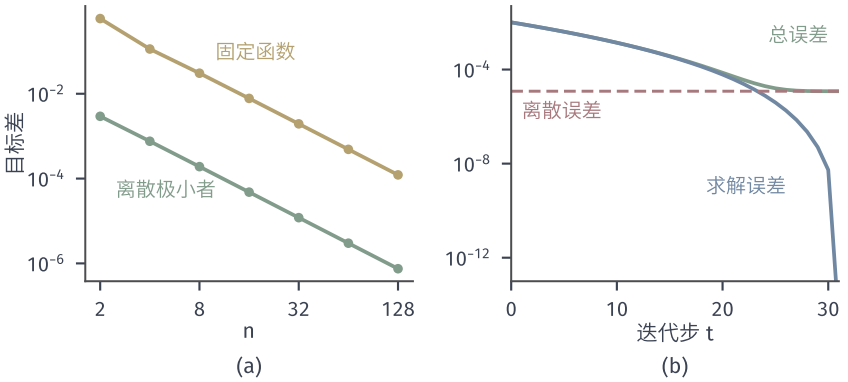


图 29.23　目标 E 的三种误差。(a) 黄色是固定函数 $x + \frac{1}{4}\sin 2\pi x$ 的线性插值的能量误差，绿色是 Ritz 解的目标差 $E(u_n) - E^\star$，两者都按 n^{-2} 衰减。(b)$n = 32$ 时用共轭梯度法从 $u = x$ 出发：蓝色是求解误差 $E(\tilde{u}_n) - E(u_n)$，绿色是总误差 $E(\tilde{u}_n) - E^\star$，红色虚线是离散误差 1.20×10^{-5}。

一般目标的收敛　对非二次的目标，能保证的结论要弱一些，证明正好回用第 29.2节的论证。这里用 $\tilde{u}_n$ 同时把求解误差包括进来。

定理 29.22　Ritz 方法的收敛　设 X、$\boldsymbol{C}$ 和 J 满足定理 29.3中反射、弱序列闭和弱序列下半连续的条件，J 的每个下水平集都有界，J 在 $\boldsymbol{C}$ 上按范数连续且处处有限，$\boldsymbol{C}_n \subseteq \boldsymbol{C}$ 非空。设对每个 $v \in \boldsymbol{C}$，存在 $v_n \in \boldsymbol{C}_n$ 使 $v_n \to v$。若 $\tilde{u}_n \in \boldsymbol{C}_n$ 满足

$$J(\tilde{u}_n) \le \inf_{\boldsymbol{C}_n} J + \varepsilon_n, \qquad \varepsilon_n \to 0, \tag{29.60}$$

则 $J(\tilde{u}_n) \to J^\star$，$\tilde{u}_n$ 有弱收敛子列，且每个弱收敛子列的极限都是最优解。

证明　任取 $\varepsilon > 0$ 和 $v \in \boldsymbol{C}$，使 $J(v) \le J^\star + \varepsilon$。取 $v_n \to v$，由连续性 $J(v_n) \to J(v)$。由式 (29.60)，

$$J^\star \le J(\tilde{u}_n) \le J(v_n) + \varepsilon_n.$$

令 $n \to \infty$，再令 $\varepsilon \to 0$，得到 $J(\tilde{u}_n) \to J^\star$。所以 $\tilde{u}_n$ 是极小化序列。

> 下水平集有界，所以序列有界，由反射性有弱收敛子列。设某子列弱收敛到 u，$\boldsymbol{C}$ 弱序列闭给出 $u\in\boldsymbol{C}$，弱序列下半连续给出 $J(u)\le J^\star$，所以 u 是最优解。 ■

定理说明 Ritz 方法产生的是一个极小化序列，第 29.2节的三关同时决定了它的命运。若 J 还满足 $J(v)-J^\star\ge\frac{\mu}{2}\|v-u^\star\|^2$，例如 J 是 μ-强凸的，则目标收敛蕴含范数收敛。

各条件的作用 条件去掉，结论就会失败。连续性保证“固定函数的能量能被逼近”。若 J 不连续，$\boldsymbol{C}_n$ 稠密也不够：存在目标使得 Lipschitz 函数上的下确界严格大于 $W^{1,1}$ 上的下确界，这称为 Lavrentiev 现象，经典例子是 Manià 给出的。这时分段线性的试探函数永远达不到真正的下确界，证明较长，读者可查阅变分法的专著。

弱序列下半连续保证极限真的最优。对目标 (29.13)，取 n 为偶数的线性元，结点值交替取 $0,\Delta,0,\Delta,\dots$ 的折线就是图 29.7的锯齿，所以

$$0<\min_{\boldsymbol{C}_n}J\le\frac{\Delta^2}{3}.$$

每个离散问题都有解，最优值也收敛到 $J^\star=0$，离散解的振幅趋于零，一致趋于 $u=0$。但 $J(0)=1$，这个极限根本不是解，原问题也没有解。计算机算出的“收敛”数字，不能代替第 29.2节的存在性论证。

数值求解误差 对二次目标，由式 (29.57)（把它用在 $\boldsymbol{C}_n$ 上，u_n 代替 $u^\star$），两种误差恰好相加：

$$J(\tilde u_n)-J^\star=\frac12 a(\tilde u_n-u_n,\tilde u_n-u_n)+\big(J(u_n)-J^\star\big).\tag{29.61}$$

第一项是求解误差，第二项是离散误差。图 29.23(b) 中，共轭梯度法的总误差下降到约 25 步后就贴住了离散误差，再多的迭代只减少第一项。所以迭代的停止精度应该与离散误差相称，把线性方程组解到机器精度是浪费。

矩阵 $\boldsymbol{A}$ 的条件数按 n^2 增长，这是第 29.3.2小节讲过的现象。用刚度矩阵作预条件，相当于换成 H^1 型内积，迭代次数就基本不随网格变化。

非二次目标 非二次目标的离散问题用前面各章的方法求解，第 7章的牛顿法尤其合适。考虑

$$J(u)=\int_0^1\Big(\frac12 u'(x)^2+\frac14 u(x)^4\Big)\,\mathrm{d}x,\qquad u(0)=0,\ u(1)=1.$$

29.1 泛函优化问题
29.2 极小值的存在
29.3 泛函的微分
29.4 最优解的判别
29.5 积分泛函
29.6 有限维近似
29.7 本章小结

它满足定理 29.6，又是严格凸的，解存在且唯一。取 $u = x + c\,x(1-x)$，用 Beta 积分把 $x^4(1+c(1-x))^4$ 逐项积分，得到一元多项式

$$f(c) = \frac{11}{20} + \frac{c}{30} + \frac{19}{105}c^2 + \frac{c^3}{280} + \frac{c^4}{2520}.$$

从 $c^{(0)} = 0$ 出发用牛顿法。第一步，$f'(0) = \frac{1}{30}$，$f''(0) = \frac{38}{105}$，于是

$$c^{(1)} = -\frac{7}{76} \approx -0.09211.$$

第二步，$f'(c^{(1)}) \approx 8.97 \times 10^{-5}$，$f''(c^{(1)}) \approx 0.35997$，于是

$$c^{(2)} \approx -0.09235.$$

此时 $f \approx 0.548462$，比 $f(0) = 0.55$ 低，再迭代目标值几乎不变。

对线性元离散的完整问题，牛顿法的 Hessian 是三对角的，每步代价正比于 n。图 29.24中，$n = 8, 32, 128$ 的三条残差曲线几乎重合，都在 3 步内到达机器精度，这称为网格无关性。这个性质表明，牛顿法的步数是函数问题本身的性质，而不是某个离散向量问题的性质。

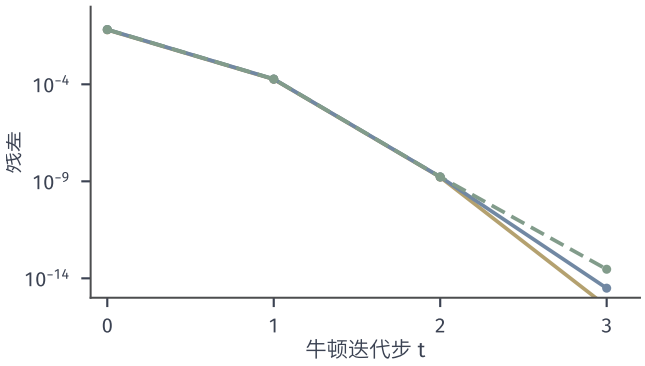


图 29.24　牛顿法的网格无关性。目标 $\int_0^1 (\frac{1}{2}u'^2 + \frac{1}{4}u^4)\,\mathrm{d}x$，从 $u = x$ 出发，线性元、梯形求积。纵轴是在 $\boldsymbol{K}^{-1}$ 范数下度量的梯度残差，$\boldsymbol{K}$ 是刚度矩阵，它对应函数空间的对偶范数。黄、蓝、绿虚线分别是 $n = 8, 32, 128$，三条线几乎重合。

29.7 本章小结

章首的问题是：未知量是一整条曲线时，怎样找最好的那一条。函数可以看成很长的向量，泛函梯度对应向量梯度，这个类比决定了本章的工作顺序：先证存在，再用微分判别，最后离散计算。

三件工具各负责什么　弱极限与下半连续性负责证明存在。无限维的闭球不紧，只能取弱收敛子列，于是可行集要弱序列闭，目标要弱序列下半连续。凸性让这两个条件可以检查，定理 29.3把它们串起来。第 29.2节的四

个反例分别对应缺少强制性、反射性、弱闭性和对导数的凸性。写出驻定方程不能代替这一步。

微分与变分负责判别候选。方向导数、Gâteaux 微分和 Fréchet 微分逐层加强，差别在于余项是否对方向一致，并且依赖范数。微分经 Riesz 表示才成为梯度，梯度依赖内积，也可能不存在。一阶条件和凸性充分性与有限维一致，二阶充分性需要统一的曲率下界，乘子法则在有限个约束下成立，无穷约束下要重新检查拓扑。

试探空间负责把函数问题转成有限维计算。Ritz 方法在二次目标上给出能量范数下的最佳逼近。固定函数的能量逼近、离散极小者的收敛、数值求解的误差是三件不同的事。

积分目标的结论 积分泛函的一阶变分经分部积分，分成内部的 Euler–Lagrange 方程和一个边界项。内部方程来自两端固定的扰动，边界条件来自放开的扰动：端点值自由给出 $F_p = 0$，端点沿曲线移动给出横截条件。这些方程都是必要条件，极小性要靠凸性或二阶条件来确认。

表 29.6 本章的问题、工具与条件。

问题	工具	关键条件
解是否存在	直接法	反射、弱闭、弱下半连续
候选怎样判别	微分与变分	所选范数下可微、凸性
方程与边界	分部积分	正则性、允许的扰动
怎样计算	Ritz 方法	稠密、连续、求解精度

边界 本章只建立优化问题本身的存在性、判别和近似。Euler–Lagrange 方程解的存在性、正则性和具体边值问题的理论属于微分方程部分；以概率分布为未知量的变分问题由卷七第 12 章“概率分布的优化与逼近”研究。离散之后的有限维问题，用本卷前面各部分的方法求解。

参考文献

A. Beck, M. Teboulle, *A Fast Iterative Shrinkage-Thresholding Algorithm for Linear Inverse Problems* In SIAM Journal on Imaging Sciences, 2009, vol. 2, no. 1, pp. 183–202.

A. Beck, M. Teboulle, *Mirror Descent and Nonlinear Projected Subgradient Methods for Convex Optimization* In Operations Research Letters, 2003, vol. 31, no. 3, pp. 167–175.

Y. Bengio, N. Léonard, A. Courville, *Estimating or Propagating Gradients Through Stochastic Neurons for Conditional Computation* In arXiv preprint arXiv:1308.3432, 2013.

D. Bertsimas, J. N. Tsitsiklis, *Introduction to Linear Optimization*, Athena Scientific, 1997.

R. G. Bland, *New Finite Pivoting Rules for the Simplex Method* In Mathematics of Operations Research, 1977, vol. 2, no. 2, pp. 103–107.

N. Boumal, *An Introduction to Optimization on Smooth Manifolds*, Cambridge University Press, 2023.

S. Boyd, L. Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004.

X. Chen, C. Liang, D. Huang, E. Real, K. Wang, Y. Liu, H. Pham, X. Dong, T. Luong, C.-J. Hsieh, Y. Lu, Q. V. Le, *Symbolic Discovery of Optimization Algorithms* In Advances in Neural Information Processing Systems 36, 2023.

F. H. Clarke, *Optimization and Nonsmooth Analysis*, SIAM, 1990.

A. Defazio, F. Bach, S. Lacoste-Julien, *SAGA: A Fast Incremental Gradient Method With Support for Non-Strongly Convex Composite Objectives* In Advances in Neural Information Processing Systems, 2014, pp. 1646–1654.

J. Duchi, E. Hazan, Y. Singer, *Adaptive Subgradient Methods for Online Learning and Stochastic Optimization* In Journal of Machine Learning Research, 2011, vol. 12, no. 61, pp. 2121–2159.

M. Frank, P. Wolfe, *An Algorithm for Quadratic Programming* In Naval Research Logistics Quarterly, 1956, vol. 3, no. 1–2, pp. 95–110.

S. Ghadimi, G. Lan, *Stochastic First- and Zeroth-Order Methods for Nonconvex Stochastic Programming* In SIAM Journal on Optimization, 2013, vol. 23, no. 4, pp. 2341–2368.

M. X. Goemans, D. P. Williamson, *Improved Approximation Algorithms for Maximum Cut and Satisfiability Problems Using Semidefinite Programming* In Journal of the ACM, 1995, vol. 42, no. 6, pp. 1115–1145.

V. Gupta, T. Koren, Y. Singer, *Shampoo: Preconditioned Stochastic Tensor Optimization* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 1842–1850.

M. Hardt, B. Recht, Y. Singer, *Train Faster, Generalize Better: Stability of Stochastic Gradient Descent* In Proceedings of the 33rd International Conference on Machine Learning, 2016, pp. 1225–1234.

G. Hinton, *Neural Networks for Machine Learning: Lecture 6*, University of Toronto, 2012, URL: https://www.cs.toronto.edu/~tijmen/csc321/slides/lecture_slides_lec6.pdf (visited on 10/04/2026).

P. J. Huber, *Robust Estimation of a Location Parameter* In The Annals of Mathematical Statistics, 1964, vol. 35, no. 1, pp. 73–101.

C. Jin, R. Ge, P. Netrapalli, S. M. Kakade, M. I. Jordan, *How to Escape Saddle Points Efficiently* In Proceedings of the 34th International Conference on Machine Learning, 2017, pp. 1724–1732.

R. Johnson, T. Zhang, *Accelerating Stochastic Gradient Descent using Predictive Variance Reduction* In Advances in Neural Information Processing Systems, 2013, pp. 315–323.

K. Jordan, Y. Jin, V. Boza, J. You, F. Cesista, L. Newhouse, J. Bernstein, *Muon: An Optimizer for Hidden Layers in Neural Networks*, Dec. 8, 2024, URL: https://kellerjordan.github.io/posts/muon/ (visited on 10/04/2026).

D. P. Kingma, J. Ba, *Adam: A Method for Stochastic Optimization* In International Conference on Learning Representations, 2015.

V. Klee, G. J. Minty, “How Good Is the Simplex Algorithm?”, in: *Inequalities III*, ed. by O. Shisha, New York: Academic Press, 1972, pp. 159–175.

G. M. Korpelevich, *The Extragradient Method for Finding Saddle Points and Other Problems* In Ekonomika i Matematicheskie Metody, 1976, vol. 12, pp. 747–756.

J. D. Lee, M. Simchowitz, M. I. Jordan, B. Recht, *Gradient Descent Only Converges to Minimizers* In Proceedings of the 29th Conference on Learning Theory, 2016, pp. 1246–1257.

I. Loshchilov, F. Hutter, *Decoupled Weight Decay Regularization* In International Conference on Learning Representations, 2019.

Y. Nesterov, *A Method for Solving the Convex Programming Problem with Convergence Rate* $O(1/k^2)$ In Soviet Mathematics Doklady, 1983, vol. 27, no. 2, pp. 372–376.

Y. Nesterov, *Efficiency of Coordinate Descent Methods on Huge-Scale Optimization Problems* In SIAM Journal on Optimization, 2012, vol. 22, no. 2, pp. 341–362.

J. Nocedal, S. J. Wright, *Numerical Optimization*, Springer, 2006, 2nd ed.

R. Pascanu, T. Mikolov, Y. Bengio, *On the Difficulty of Training Recurrent Neural Networks* In Proceedings of the 30th International Conference on Machine Learning, 2013, pp. 1310–1318.

B. T. Polyak, *Some Methods of Speeding up the Convergence of Iteration Methods* In USSR Computational Mathematics and Mathematical Physics, 1964, vol. 4, no. 5, pp. 1–17.

S. J. Reddi, S. Kale, S. Kumar, *On the Convergence of Adam and Beyond* In International Conference on Learning Representations, 2018.

H. Robbins, S. Monro, *A Stochastic Approximation Method* In The Annals of Mathematical Statistics, 1951, vol. 22, no. 3, pp. 400–407.

R. T. Rockafellar, *Convex Analysis*, Princeton University Press, 1970.

N. Shazeer, M. Stern, *Adafactor: Adaptive Learning Rates with Sublinear Memory Cost* In Proceedings of the 35th International Conference on Machine Learning, 2018, pp. 4596–4604.

M. Sion, *On General Minimax Theorems* In Pacific Journal of Mathematics, 1958, vol. 8, no. 1, pp. 171–176.

索引

一次罚函数，l1 penalty function，955
一阶驻点，first-order stationary point，355
上图，epigraph，393，784，876
上界代理，majorizer，439
下凸包，lower convex hull，1157
下半连续，lower semicontinuous，12
下水平集，sublevel set，12
下降引理，descent lemma，166
下降方向，descent direction，23
下降比，reduction ratio，340
不可行，infeasible，6
世代距离，generational distance，1191
两阶段法，two-phase method，90
严格互补，strictly complementary，129
严格凸函数，strictly convex function，19
严格可行，strictly feasible，124
严格局部最优解，strict local minimizer，7
严格鞍点，strict saddle point，355
个人最好位置，personal best，666
中心化参数，centering parameter，131
中心差分，central difference，589
中心路径，central path，127
临界锥，critical cone，755
久期方程，secular equation，326
乐观梯度下降—上升，optimistic gradient descent-ascent，1233
乐观模型，optimistic model，1246
二次惩罚法，quadratic penalty method，945
二次收敛，quadratic convergence，247
二次模型，quadratic model，321
二次约束二次规划，quadratically constrained quadratic program，883
二次罚函数，quadratic penalty function，945
二次规划，quadratic program，846
二阶修正，second-order correction，1035
二阶变分，second variation，1311
二阶回缩，second-order retraction，1100
二阶锥，second-order cone，862
二阶锥规划，second-order cone program，862
二阶驻点，second-order stationary point，355
互补松弛，complementary slackness，66
互补约束规划，mathematical program with complementarity constraints，1271
交叉，crossover，661
交替方向乘子法，alternating direction method of multipliers，984
交替最小二乘，alternating least squares，476
交替极小化，alternating minimization，475
亲代，parents，646
人工变量，artificial variable，90
代理模型，surrogate model，438
仿射不变性，affine invariance，244
仿射尺度方向，affine-scaling direction，134
优化误差，optimization error，579
优化问题，optimization problem，5
伴随方程，adjoint equation，1255
伴随法，adjoint method，838
信赖域，trust region，320
信赖域子问题，trust-region subproblem，322
修正 Cholesky 分解，modified Cholesky factorization，262
修正 Newton 法，modified Newton method，260
修正单纯形法，revised simplex method，103
热启动，warm start，111，947，1015，1182，1253
熵势，entropic potential，924
狗腿法，dogleg method，332
独立复评，independent re-evaluation，621
球平滑，ball smoothing，599
理想点，ideal point，1150
目标函数，objective function，5
目标泛函，objective functional，1289
目标空间，objective space，1144

直接法，direct method，1293
直通估计，straight-through estimator，576
相对光滑，relative smoothness，928
相对内部，relative interior，397
知识梯度，knowledge gradient，699
矩阵正则化，matrix regularization，1061
积分泛函，integral functional，1316
稳定中心，stability center，442
稳定流形，stable manifold，374
空步，null step，442
等价改写，equivalent reformulation，875
简单遗憾，simple regret，718
算法稳定性，algorithmic stability，580
粒子群优化，particle swarm optimization，665
精确线搜索，exact line search，188
精确罚函数，exact penalty function，955
精英保留，elitism，663，1184
紧集，compact set，11
累积遗憾，cumulative regret，719
约化 Hessian，reduced Hessian，853，1003
约化成本，reduced cost，80
约化梯度，reduced gradient，932
约化目标，reduced objective，931
约束指标函数，constraint indicator function，9
约束资格，constraint qualification，738
线性化锥，linearized cone，736
线性无关约束资格，linear independence constraint qualification，739
线性松弛，linear relaxation，69
线性矩阵不等式，linear matrix inequality，868
线性规划，linear programming，42
缩放乘子，scaled dual variable，986
罚参数，penalty parameter，945
置信下界，lower confidence bound，696
能垒，energy barrier，641
自协调，self-concordant，1083
自然梯度，natural gradient，657
自然演化策略，natural evolution strategy，656
自然边界条件，natural boundary condition，1321
自由变量，free variable，45
范数裁剪，norm clipping，572
解映射，solution map，804
解析中心，analytic center，128
解码，decoding，659
评价，evaluation，631
评价函数，merit function，1025
试探函数，trial function，1324
试探空间，trial space，1325
误差比例，forcing term，268
读数，reading，586
谱修正，spectral modification，261
贝叶斯优化，Bayesian optimization，682
负曲率方向，negative curvature direction，30
负熵，negative entropy，432
贪心块坐标下降，greedy block coordinate descent，463
超体积，hypervolume，1189
超参数，hyperparameter，691
超梯度，supergradient，965
超梯度，hypergradient，1255
超线性收敛，superlinear convergence，270，313
轮，epoch，458
软阈值，soft thresholding，409
边缘似然，marginal likelihood，691
过滤器，filter，1029，1063
近似二阶驻点，approximate second-order stationary point，384
远离步，away step，919
迭代展开，unrolled differentiation，1263
迭代软阈值算法，iterative shrinkage-thresholding algorithm，414
迭代重加权最小二乘，iteratively reweighted least squares，439
迹内积，trace inner product，866
退化基，degenerate basis，58
退化驻点，degenerate stationary point，29
适应度，fitness，661
适当函数，proper function，9
选择偏差，selection bias，621
选择压力，selection pressure，661
选解规则，selection rule，805
逐坐标裁剪，coordinate-wise clipping，571
遗传算法，genetic algorithm，659
邻域，neighborhood，633
邻域最好位置，neighborhood best，666
邻近映射，proximal mapping，406
邻近梯度映射，proximal gradient mapping，421
邻近梯度法，proximal gradient method，413
邻近点法，proximal point method，410
采集函数，acquisition function，693
重启，restart，234
重球法，heavy ball method，209
重组，recombination，648
锥对偶问题，conic dual problem，861
锥规划，conic program，860

锦标赛选择，tournament selection，660
镜像下降法，mirror descent，922
长度尺度，length scale，687
闭凸锥，closed convex cone，860
阈值约束法，epsilon-constraint method，1157
阻尼 BFGS，damped BFGS，1023
阻尼 Newton 法，damped Newton method，251
阻挡约束，blocking constraint，1010
限定间隙，restricted gap，1210
随机块坐标下降，randomized block coordinate descent，461
随机搜索，random search，630
随机方向差分，random-direction difference，594
随机梯度下降，stochastic gradient descent，515
随机邻近梯度法，stochastic proximal gradient method，528
随机重排，random reshuffling，513
随机重球法，stochastic heavy ball method，546
隐式微分，implicit differentiation，1255
障碍参数，barrier parameter，1076
障碍子问题，barrier subproblem，1044
障碍法，barrier method，1051
零阶优化，zeroth-order optimization，585
零阶随机优化，zeroth-order stochastic optimization，585
零阶随机梯度方法，zeroth-order stochastic gradient method，610
非均匀抽样，non-uniform sampling，536
非基变量，nonbasic variable，80
非基本变量，nonbasic variable，931
非支配存档，non-dominated archive，1182
非支配排序，non-dominated sorting，1183
非精确 Newton 法，inexact Newton method，268
非线性共轭梯度法，nonlinear conjugate gradient method，225
鞍点，saddle point，24
鞍点间隙，saddle gap，1209
顶点覆盖，vertex cover，74
预处理，presolve，143
预测—校正，predictor-corrector，139
预测下降，predicted reduction，328
驻点，stationary point，24
高斯变异，Gaussian mutation，647
高斯平滑，Gaussian smoothing，599
高斯过程，Gaussian process，686
黎曼 BFGS，Riemannian BFGS，1125
黎曼 Hessian，Riemannian Hessian，1096
黎曼 Newton 法，Riemannian Newton method，1118
黎曼信赖域，Riemannian trust region，1129
黎曼共轭梯度，Riemannian conjugate gradient，1115
黎曼度量，Riemannian metric，1091
黎曼梯度，Riemannian gradient，1093
黎曼梯度下降，Riemannian gradient descent，1110
黑箱优化，black-box optimization，682
齐次模型，homogeneous model，143
齐次自对偶嵌入，homogeneous self-dual embedding，144

Armijo 条件，Armijo condition，177

BFGS 更新，BFGS update，290
Bland 规则，Bland's rule，100
Bregman 距离，Bregman distance，921

Cauchy 步，Cauchy step，330，1130
Clarke 次微分，Clarke subdifferential，399

Dantzig 规则，Dantzig's rule，84
Dennis–Moré 条件，Dennis-Moré condition，314
DFP 更新，DFP update，291
Dikin 椭球，Dikin ellipsoid，1083

Euler–Lagrange 方程，Euler–Lagrange equation，1318

Fenchel 对偶，Fenchel duality，786
Fenchel–Young 不等式，Fenchel–Young inequality，781
Fisher 信息矩阵，Fisher information matrix，657
Fletcher–Reeves 公式，Fletcher–Reeves formula，226
Frank–Wolfe 法，Frank-Wolfe method，910
Frank–Wolfe 间隙，Frank-Wolfe gap，916
Fréchet 可微，Fréchet differentiable，1301

Gâteaux 可微，Gâteaux differentiable，1301
Gâteaux 微分，Gâteaux derivative，1301
Gauss–Southwell 规则，Gauss–Southwell rule，464
Gibbs 分布，Gibbs distribution，637

Hessian 向量积，Hessian-vector product，273，1257
Hilbert 梯度，Hilbert gradient，1305
Huber 函数，Huber function，425

KKT 条件，Karush-Kuhn-Tucker conditions，749
KKT 点，KKT point，749
KKT 矩阵，KKT matrix，825，854，1002

Lagrange Hessian，1057
Lagrange 乘子，Lagrange multiplier，744

Lagrange 函数，Lagrangian，746
Lagrange 鞍点，Lagrangian saddle point，798
Lasso，398

Mangasarian–Fromovitz 约束资格，Mangasarian-Fromovitz constraint qualification，742
Maratos 效应，Maratos effect，1035
MM 方法，majorization-minimization，439
Moreau 包络，Moreau envelope，427

Nesterov 加速梯度法，Nesterov accelerated gradient method，216
Nesterov 平滑，Nesterov smoothing，430
Newton-CG，272
Newton 减量，Newton decrement，252
Newton 方向，Newton direction，240
Newton 方程，Newton equation，240
Newton 法，Newton's method，240
NSGA-II，non-dominated sorting genetic algorithm II，1183

Pareto 前沿，Pareto front，1147
Pareto 最优，Pareto optimal，1146
Pareto 解集，Pareto set，1147
Pareto 驻定，Pareto stationary，1166
Polak–Ribière–Polyak 公式，Polak–Ribière–Polyak formula，226
Polyak 步长，Polyak step size，404

Rayleigh 商，Rayleigh quotient，1094
Ritz 方法，Ritz method，1325

Schur 补，Schur complement，879
Slater 条件，Slater's condition，789
SVRG，stochastic variance reduced gradient，538

Thompson 采样，Thompson sampling，697

停止梯度，stop-gradient，576
充分下降条件，sufficient decrease condition，177
充分模型下降，sufficient model decrease，331
先验，prior，684
光滑常数，smoothness constant，164
入基变量，entering variable，83
全局最优解，global minimizer，7
全局鞍点，global saddle point，1203
全幺模矩阵，totally unimodular matrix，72
共享样本，shared sample，588
共同下降方向，common descent direction，1165
共同下降残差，common descent residual，1187
内层解集，lower-level solution set，1243
内点，interior point，24
决策变量，decision variable，5
决策空间，decision space，1144
几何降温，geometric cooling，644
凸共轭，convex conjugate，778
凸函数，convex function，17
凸包，convex hull，395，1165
凸集，convex set，16
出基变量，leaving variable，83
函数平滑误差，function smoothing error，625
分离超平面，separating hyperplane，784
切锥，tangent cone，730
初始设计，initial design，703
到边界的比例规则，fraction-to-the-boundary rule，134
前向差分，forward difference，589
剩余变量，surplus variable，45
割平面模型，cutting-plane model，442
割线条件，secant condition，286
加性噪声，additive noise，586
加权 Chebyshev 标量化，weighted Chebyshev scalarization，1161
加权和法，weighted-sum method，1152
加速邻近坐标梯度，accelerated proximal coordinate gradient，469
加速邻近梯度法，fast iterative shrinkage-thresholding algorithm，417
动量，momentum，209
势函数，potential function，219，921
包络定理，envelope theorem，815
半正定松弛，semidefinite relaxation，884
半正定规划，semidefinite program，866
半空间，halfspace，48
协方差核，covariance kernel，686
协方差矩阵适应演化策略，covariance matrix adaptation evolution strategy，650
单点估计，one-point estimator，603
单点查询，single-point query，588
单纯形法，simplex method，78
单纯形表，simplex tableau，102
单调算子，monotone operator，1227
原始—对偶缩放，primal-dual scaling，1081
原始残差，primal residual，988

原始问题，primal problem，61
参考点，reference point，1161，1189
双共轭，biconjugate，783
双层优化，bilevel optimization，1243
双循环递推，two-loop recursion，305
双点估计，two-point estimator，604
反向世代距离，inverted generational distance，1191
取舍，trade-off，1148
变分不等式，variational inequality，735，904
变异，mutation，661
变量块，variable block，450
可行性恢复，feasibility restoration，1034，1064
可行性残差，feasibility residual，37
可行恢复，feasibility restoration，933
可行方向，feasible direction，31，1310
可行点，feasible point，5
可行集，feasible set，5
可达目标集，attainable objective set，1144
同时扰动随机逼近，simultaneous perturbation stochastic approximation，596
后代，descendant，646
后验，posterior，684
向量搬运，vector transport，1107
含参问题，parametric problem，803
含噪期望改进，noisy expected improvement，708
噪声底，noise floor，519
回溯线搜索，backtracking line search，178
回缩，retraction，1100
困难情形，hard case，327
均值函数，mean function，686
坐标差分，coordinate difference，591
块上界，block upper bound，482
块上界最小化，block successive upper-bound minimization，482
块光滑常数，block smoothness constant，464
块坐标 Newton 法，block coordinate Newton method，474
块坐标下降，block coordinate descent，456
块坐标梯度下降，block coordinate gradient descent，466
块梯度映射，block gradient mapping，489
块邻近梯度，block proximal gradient，486
基变量，basic variable，80
基恢复，crossover，148
基本变量，basic variable，931
基本可行解，basic feasible solution，49
基本解，basic solution，49
基矩阵，basis matrix，49
增广 Lagrange 函数，augmented Lagrangian，973
增广 Lagrange 法，augmented Lagrangian method，975
复合目标，composite objective，413
复合驻点，composite stationary point，421
外推点，extrapolation point，216
外梯度法，extragradient method，1228
多梯度下降算法，multiple-gradient descent algorithm，1172
多目标优化，multi-objective optimization，1143
多面体，polyhedron，48
大 M 法，big-M method，95
字典序规则，lexicographic rule，102
实质步，serious step，442
实际下降，actual reduction，328
宽邻域，wide neighborhood，1064
密度，density，1316
对偶上升法，dual ascent，966
对偶函数，dual function，767
对偶分解，dual decomposition，969
对偶单纯形法，dual simplex method，106
对偶松弛，dual slack，61
对偶残差，dual residual，988
对偶范数，dual norm，779
对偶锥，dual cone，860
对偶问题，dual problem，61
对偶间隙，duality gap，61，772
对数和指数函数，log-sum-exp function，432
对数降温，logarithmic cooling，642
对数障碍，logarithmic barrier，124
对称秩一更新，symmetric rank-one update，299
小批量，mini-batch，532
局部 Pareto 最优，locally Pareto optimal，1147
局部二次模型，local quadratic model，239
局部二次规划，local quadratic program，999
局部最优解，local minimizer，7
局部最小点，local minimizer，728
局部极小分支，local minimizer branch，805
局部极小极大点，local minimax point，1239
局部极小点，local minimizer，1309
局部误差界，local error bound，959
局部鞍点，local saddle point，1204
工作集，working set，1009
差商，difference quotient，589
平方指数核，squared exponential kernel，686
平滑目标，smoothed objective，599
平行移动，parallel transport，1107
广义约化梯度法，generalized reduced gradient method，930

序列二次规划，sequential quadratic programming，999
弱 Pareto 最优，weakly Pareto optimal，1146
弱对偶，weak duality，61，772
弱序列下半连续，weakly sequentially lower semicontinuous，1292
弱序列闭，weakly sequentially closed，1292
弹性子问题，elastic subproblem，1033
强凸，strongly convex，21
强凸常数，strong convexity constant，21
强制的，coercive，14
强对偶，strong duality，65，788
强 Wolfe 条件，strong Wolfe conditions，183
影子价格，shadow price，113
得分函数，score function，656
循环，cycling，99
循环块坐标下降，cyclic block coordinate descent，458
微分回缩，differentiated retraction，1108

悲观模型，pessimistic model，1246
惯性，inertia，837，1019
成对查询，paired query，588
成对步，pairwise step，919
截断共轭梯度法，truncated conjugate gradient method，335，1130
截断误差，truncation error，590
扩展实值函数，extended real-valued function，9
扰动尺度，perturbation scale，589
扰动梯度法，perturbed gradient method，377
投影，projection，897
投影搬运，projection transport，1107
投影梯度残差，projected gradient residual，904
投影梯度法，projected gradient descent，900
折叠点，fold point，1054
拉丁超立方抽样，Latin hypercube sampling，703
拉回，pullback，1105
拟牛顿法，quasi-Newton method，286
拥挤距离，crowding distance，1183
指数更新，exponentiated update，924
指数移动平均，exponential moving average，561
指示函数，indicator function，9
换基，pivot，83
控制变量，control variate，538
支撑函数，support function，779
支撑点，supported point，1155
支撑线，supporting line，1152
支配，dominate，1145
改进概率，probability of improvement，693
整数线性规划，integer linear programming，69
整数间隙，integrality gap，71
方向导数，directional derivative，23，1301
无下界，unbounded below，7
无界可行方向，unbounded feasible direction，59
曲率条件，curvature condition，183，288
替代梯度，surrogate gradient，576
最优值，optimal value，6
最优值函数，value function，804
最优性残差，optimality residual，38
最优解，optimal solution，6
最优面，optimal face，129
最坏值函数，worst-case value function，1198
最小化序列，minimizing sequence，11
最差点，nadir point，1151
有效定义域，effective domain，9
有效步长，effective step size，546
有限和目标，finite-sum objective，506
有限步目标，finite-step objective，1248
有限记忆 BFGS，limited-memory BFGS，304
期望改进，expected improvement，694
期望目标，expected objective，508
权重衰减，weight decay，567
束方法，bundle method，442
条件函数，conditional function，450
条件子问题，conditional subproblem，450
条件无偏，conditionally unbiased，511，587
条件梯度法，conditional gradient method，910
松弛变量，slack variable，45，1055
极值曲线，extremal，1318
极因子，polar factor，557
极小极大问题，minimax problem，1194
极点，extreme point，48
查询点，query point，586
标准型，standard form，44
标量化，scalarization，1152
标量子问题误差，scalar subproblem error，1187
梯度 Lipschitz 条件，gradient Lipschitz condition，164
梯度下降—上升，gradient descent-ascent，1219
梯度下降法，gradient descent method，199
梯度累积，gradient accumulation，534
梯度裁剪，gradient clipping，571
检查点，checkpointing，1266
概率代理，probabilistic surrogate，685
模拟退火，simulated annealing，636

横截条件，transversality condition，1323
次微分，subdifferential，393
次梯度，subgradient，393
次梯度法，subgradient method，400
正规方程，normal equations，133
残差平衡，residual balancing，989
比值检验，ratio test，82，1010
法锥，normal cone，399，734
泛函，functional，1289
泛函优化问题，functional optimization problem，1289
活动约束，active constraint，727
活动集，active set，727，1009
演化策略，evolution strategy，646
演化路径，evolution path，651
Wolfe 条件，Wolfe conditions，183

Zoutendijk 条件，Zoutendijk condition，186，311